

主动推断

心智、大脑与行为中的自由能原理

Active Inference

Thomas Parr, Giovanni Pezzulo, Karl J. Friston

原版 · The MIT Press · 2022
Model: gpt-6.1-terra（2026-11-04 续译）；gpt-6.1-sol
（2026-11-05–06 续译；早期初译待核）
审核：曹溪能
Updated: 2026-11-06

译本说明

本稿包含冻结 2022 版前置材料、第 1–10 章、附录 A–C、全书 36 条章注、320 条原书参考文献与原书索引的本地审校候选. 独立内容审校、独立源码重建与最终主控验收尚待完成. 依据本地 2022 年 MIT Press 版；本稿不用于公开分发.

审核：曹溪能

版权信息

© 2022 Massachusetts Institute of Technology.
This work is subject to a Creative Commons CC BY-NC-ND license. Subject to such license, all rights are reserved.



本作品受知识共享署名—非商业性使用—禁止演绎（CC BY-NC-ND）许可约束. 在该许可约束下，保留所有权利. 译文公开传播所需许可尚未核实.

麻省理工学院出版社感谢为本书草稿提供意见的匿名同行评审专家. 学术专家慷慨付出的工作对于确立本社出版物的权威性和质量至关重要. 我们感谢这些未署名读者所作的贡献.

本书由 Westchester Publishing Services 使用 Stone Serif 和 Stone Sans 字体排版. 美国国会图书馆编目数据可供查阅. 编目姓名：Parr, Thomas, 1993–，作者；Pezzulo, Giovanni，作者；Friston, K. J. (Karl J.)，作者.

题名：Active inference: the free energy principle in mind, brain, and behavior / Thomas Parr, Giovanni Pezzulo, and Karl J. Friston.

出版信息：Cambridge, Massachusetts: The MIT Press, [2022]；含参考文献与索引.

标识符：LCCN 2021023032；ISBN 9780262045353（精装）.

主题（LCSH）：知觉；推断；神经生物学；人类行为模型；知识论；贝叶斯统计决策理论.

分类：LCC BF311 .P31366 2022；DDC 153—dc23. 国会图书馆记录：https://lccn.loc.gov/2021023032.

目录

前言 4

第一部分 6

第 1 章 概览 6

第 2 章 通向主动推断的低路径 13

第 3 章 通向主动推断的高路径 30

第 4 章 主动推断的生成模型 43

第 5 章 消息传递与神经生物学 59

第二部分 73

第 6 章 设计主动推断模型的步骤 74

第 7 章 离散时间中的主动推断 86

第 8 章 连续时间中的主动推断 107

第 9 章 基于模型的数据分析 122

第 10 章 主动推断：有感知行为的统一理论 133

附录 A 数学背景 149

附录 B 主动推断的方程 160

附录 C Matlab 代码的带注释示例 170

注释 176

参考文献 180

原书索引 201

术语索引 204

前言

Karl Friston

主动推断是一种理解有感知行为的方式. 你正在阅读这些文字，这一事实本身就意味着你正在进行主动推断：由于相信自己会有所收获，你正以一种特定的方式主动采样世界. 你的眼睛正在触探这一页，因为这种行动能够消解你对于接下来会看到什么，以及这些文字传达什么的疑惑. 简言之，主动推断把行动带入知觉，将知觉视作知觉推断或假设检验. 主动推断还更进一步，把规划视为推断：推断自己接下来会做什么，以消解关于自身所体验世界的不确定性.

为说明主动推断的简洁之处，以及我们试图解释的现象，请将指尖轻轻放在腿上，静止一两秒钟. 现在，你觉得腿的表面粗糙还是光滑？如果你必须移动手指才能感受到粗糙或光滑，那么你已经发现了主动推断的一项基本原理. 感觉就是触探；看见就是观看；听见就是倾听. 这种触探不一定要外显：我们可以把注意力转向某一事物，以隐蔽的方式行动. 简言之，我们不只是试图理解自己的感觉，还必须主动创造自己的感官世界. 在下文中，我们将看到为什么必定如此，以及为什么我们所感知、所做或所规划的一切都处在一项生存命令的范围内：自我证成（self-evidencing）.

主动推断所涉及的不只是阅读或获取知识. 从一种观点看，一切生物和粒子都凭其存在而从事主动推断. 这听起来或许是一个很强的论断；不过，它表明主动推断继承了一项自由能原理：该原理将存在等同于自我证成，并将自我证成等同于一种能动的推断. 然而，本书并不讨论有感知系统的物理学，而是着重讨论这一物理学对于理解大脑如何运作的意义. 这种理解并非易事，几千年的自然哲学和几百年的神经科学研究就是明证. 尽管主动推断的根源可以追溯到从第一性原理出发对自组织行为所作的描述，即类似于哈密顿驻作用量原理的变分原理，但当我们问某个特定的大脑如何运作，以及它与另一个大脑有何不同时，第一性原理并不能提供多少帮助. 例如，认同自然选择的进化论，对于理解为什么我有两只眼睛或者为什么我会说法语，丝毫没有帮助. 本书关注如何利用原理来构建神经科学和人工智能中的关键问题. 为此，我们必须超越原理，掌握这些原理所适用的机制.

因此，主动推断及其相伴的贝叶斯力学为我们如何知觉、规划和行动的问题提供了框架. 关键在于，它并不旨在取代行为心理学、决策理论和强化学习等其他框架；相反，它希望将所有这些已取得显著成功的方法纳入一个统一框架. 下文将特别注意把心理学、认知神经科学、能动主义、动物行为学等领域的关键概念，同主动推断中的信念更新计算及其相关过程理论联系起来.

所谓过程理论，是指关于信念更新如何由具身大脑及其之外的神经元过程和其他生物物理过程实现的理论. 迄今为止，主动推断研究提供了一套相当直观的计算架构和仿真工具，既可用于模拟运作中的大脑的各个方面，也使人们能够检验有关不同计算架构的假设. 不过，这些工具只解决了一半的问题. 主动推断的核心是生成模型，即对于外部世界中不可观测的原因如何产生可观测后果——我们的感觉——的概率表征. 如何正确构建生成模型，使之能够恰当地解释任何实验被试或生物的有感知行为，是一项重大挑战.

本书试图解释如何应对这一挑战. 第一部分建立第二部分所需的基本思想和形式体系；第二部分说明如何在实践中应用它们. 简言之，本书面向希望利用主动推断来模拟

和建模有感知行为、服务于科学研究或可能的人工智能应用的读者. 因此，本书着重于理解和实现主动推断方案所必需的思想与方法，而不在有感知系统的物理学或哲学问题上分散注意力.

Karl Friston 的说明

我得坦白一件事：本书的大部分内容不是我写的. 更准确地说，我没有被允许这样做. 本书的目标要求清晰简洁的文风，而这是我做不到的. 尽管我获准悄悄加入几个自己喜爱的词语，下文仍是对 Thomas 和 Giovanni 的证明：证明他们对相关问题有深刻理解，更重要的是，证明他们在一切意义上都具有心智理论.

致谢

我们衷心感谢朋友和同事们提供的宝贵帮助，特别是伦敦大学学院 Wellcome 人类神经影像中心理论神经生物学组的历任成员、意大利国家研究委员会认知科学与技术研究所的行动中的认知（CONAN）实验室，以及众多国际合作者；他们都是本书所述思想发展的重要参与者. 这个年轻而不断壮大的社群慷慨地提供了智力支持与动力. 此外，我们感谢麻省理工学院出版社的 Robert Prior 和 Anne-Marie Bono 在本书编写期间给予的陪伴与建议，也感谢 Jakob Hohwy 和其他深思熟虑的评审人提供指导. 最后，我们感谢为我们的研究提供资助的机构：KJF 获 Wellcome Trust 首席研究员奖助金资助（编号 088130/Z/09/Z）；GP 获欧洲研究理事会资助（资助协议编号 820213，ThinkAhead），并获欧盟地平线 2020 研究与创新框架计划资助（专项资助协议编号 945539，人脑计划 SGA3）.

第一部分

Chapter 1

概览

机遇偏爱有准备的头脑.
—Louis Pasteur

1.1 引言

本章介绍主动推断试图回答的主要问题：生物体如何在与环境进行适应性交互的同时维持自身存在？我们讨论从规范性视角研究这一问题的动机；这种视角从第一性原理出发，进而阐明其认知和生物学含义. 此外，本章简要介绍本书的结构，包括全书的两个部分：第一部分旨在帮助读者理解主动推断，第二部分旨在帮助读者将主动推断用于自己的研究.

1.2 生物体如何维持自身存在并作出适应性行动？

生物体不断与环境（包括其他生物）相互作用. 它们发出改变环境的行动，并从环境接收感觉观测，如图 1.1 所示.

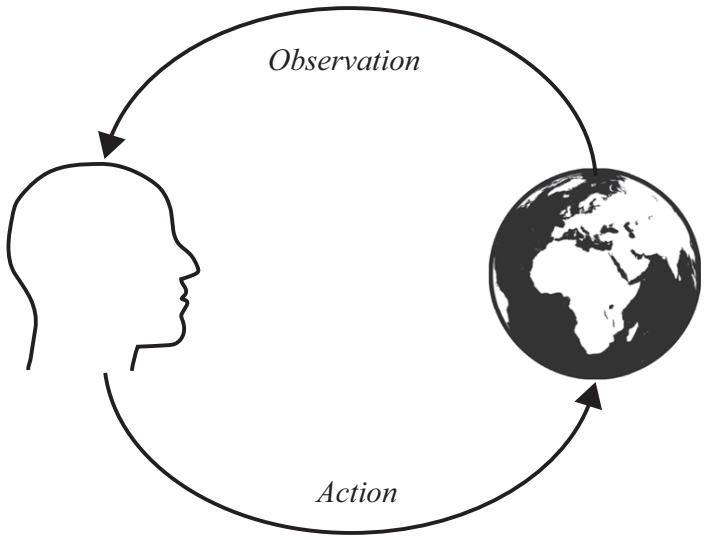


图 1.1: 将生物与环境相互连接的行动—知觉循环. “环境” 一词有意采用一般含义；在我们讨论的例子中，它可以包括物理世界、身体、社会环境等. 图中 Observation 为观测，Action 为行动.

生物体只有对行动—知觉循环施加适应性控制，才能维持身体的完整性. 这意味着通过行动获取感觉观测：这些观测或是对应于期望的结果或目标（例如，较简单生物获得可靠的营养和庇护所伴随的感觉，或者较复杂生物获得朋友和工作所伴随的感觉），或是有助于理解世界（例如，向生物体提供周围环境的信息）.

与环境形成适应性的行动—知觉循环，对生物体提出了严峻挑战. 这在很大程度上是由于循环的递归性质：每一次由前一行动获取的观测，都会改变我们如何决定下一次行动，以获取下一次观测. 控制和适应的可能方式很多，但真正有用的寥寥无几. 尽管如此，在进化过程中，生物体还是发展出了应对生存的基本挑战的适应性策略. 这些策略的认知复杂程度各不相同：较简单的生物采用较简单、较固定的解决方式，例如细菌沿营养物质梯度移动；较高级的生物则采用认知要求更高、更灵活的方式，例如人类为实现远期目标而规划. 这些策略被选取并发挥作用的时间尺度也各不相同：从对环境威胁的简单反应，或在进化时间尺度上出现的形态适应，到文化学习或发育学习期间形成的行为模式，再到那些需要在与行动和知觉相近的时间尺度上运作的认知过程，例如注意和记忆.

1.3 主动推断：从第一性原理出发理解行为

这种多样性对生物学而言是一件幸事，却给大脑与心智的形式理论带来了挑战. 大体而言，我们可以从两种视角看待这一问题. 一种视角认为，不同的生物适应、神经过程（例如突触间的信息交换和大脑网络）及认知机制（例如知觉、注意和社会互动）有很强的特殊性，需要各自专门的解释. 这将导致哲学、心理学、神经科学、动物行为学、生物学、人工智能和机器人学等领域中的理论不断增多，却几乎没有希望将其统一起来. 另一种视角则认为，尽管生物体的行为、认知与适应表现各异，其核心方面仍可从第一性原理出发得到一致的解释.

这两种可能性对应两种不同的研究纲领，在某种程度上也对应对待科学的不同态度："整洁派"与"邋遢派"（这两个术语由 Roger Shank 提出）. 整洁派总是寻求在大脑和心智现象的（表面）异质性之下实现统一. 这通常体现为设计自上而下的规范性[1]模型：从第一性原理出发，尽可能多地推导出有关大脑和心智的结论. 相反，邋遢派接受这种异质性，关注需要专门解释的细节. 这通常体现为设计自下而上的模型：从数据出发，采用任何有效的方法解释复杂现象，包括对不同现象采用不同的解释.

是否有可能像整洁派所设想的那样，从第一性原理出发解释形形色色的生物和认知现象？是否可能存在一个统一的框架来理解大脑和心智？

本书对这些问题作出肯定的回答，并提出将主动推断作为理解大脑和心智的规范性方法. 我们对主动推断的讨论从第一性原理出发，阐明其认知和生物学含义.

1.4 本书结构

本书由两部分组成，分别面向希望理解主动推断的读者和希望在自己的研究中运用主动推断的读者. 第一部分从概念和形式两个方面介绍主动推断，并将其置于现有认知理论的背景之中. 这一部分的目标是对主动推断作出全面、形式化且自足的介绍，阐明其主要概念及其对大脑和认知研究的意义.

第二部分通过具体的计算模型实例，说明如何使用主动推断解释知觉、注意、记忆和规划等认知现象. 这一部分旨在帮助读者理解现有的主动推断计算模型，并设计新模型. 简言之，本书分为理论（第一部分）和实践（第二部分）.

1.4.1 第一部分：主动推断的理论

主动推断是一种规范性框架，用来刻画生物体中贝叶斯最优[2]的行为和认知. 其规范性体现在这样一种观点中：生物体行为和认知的各个方面都遵循同一项命令，即最小化其感觉观测的惊异. 惊异必须从技术意义上理解：它度量智能体当前的感觉观测与其偏好的感觉观测之间的差异；后者是保持其完整性的观测，例如鱼处在水中. 关键在于，不能通过被动观察环境来最小化惊异；智能体必须对其行动—知觉循环施加适应性控制，以获取期望的感觉观测. 这就是主动推断中 “主动” 的含义.

由于后文将要阐明的技术原因，最小化惊异是一项具有挑战性的问题. 主动推断为此提供了一种解法：它假设，即使生物体不能直接最小化惊异，也能最小化一个称为（变分）自由能的替代量. 这个量可以通过神经计算响应感觉观测（并预期感觉观测）而最小化. 对自由能最小化的强调揭示了主动推断与启发它的（第一性）原理——自由能原理——之间的关系（Friston 2009）.

自由能最小化似乎是解释生物现象的一个非常抽象的出发点. 然而，我们可以由此推导出一系列形式和经验上的含义，并探讨认知与神经理论中的若干核心问题. 这些问题包括：参与自由能最小化的变量如何在神经元群体中编码；最小化自由能的计算如何对应知觉、行动选择和学习等具体认知过程；以及主动推断智能体最小化其自由能时会产生何种行为.

如上述主题所示，本书主要关注生物体层面——无论较简单的生物体（例如细菌）还是较复杂的生物体（例如人）——的主动推断和自由能最小化，以及它们的行为、认知、社会和神经过程. 澄清这一点有助于将本书对主动推断的讨论置于更一般的自由能原理（FEP）之中. 自由能原理讨论神经信息处理之外更广泛的生物现象和时间尺度上的自由能最小化，范围从进化到细胞和文化（Friston, Levin et al. 2015; Isomura and Friston 2018; Palacios, Razi et al. 2020; Veissière et al. 2020）；这些内容超出了本书的范围.

可以沿两条路径引出主动推断：高路径和低路径，见图 1.2. 这两条路径提供了两个不同但高度互补的主动推断视角：

- 主动推断的高路径从生物体如何在世界中维持自身存在并作出适应性行动这一问题出发，将主动推断引作这些问题的规范性解法. 高路径视角有助于理解主动推断的规范性质：生物体必须做什么才能应对其生存的根本挑战（最小化自由能），以及为什么要这样做（间接最小化感觉观测的惊异）.

- 主动推断的低路径从贝叶斯脑概念出发，将大脑视为一个试图优化其感觉输入之成因的概率表征的推断引擎. 它进而将主动推断引作这一推断问题的一种具有一定生物合理性的特定变分近似；否则该问题难以求解. 低路径视角有助于说明主动推断智能体如何最小化自由能，从而将主动推断不仅作为一项原理，而且作为对认知功能及其神经元基础的机制解释，即过程理论.

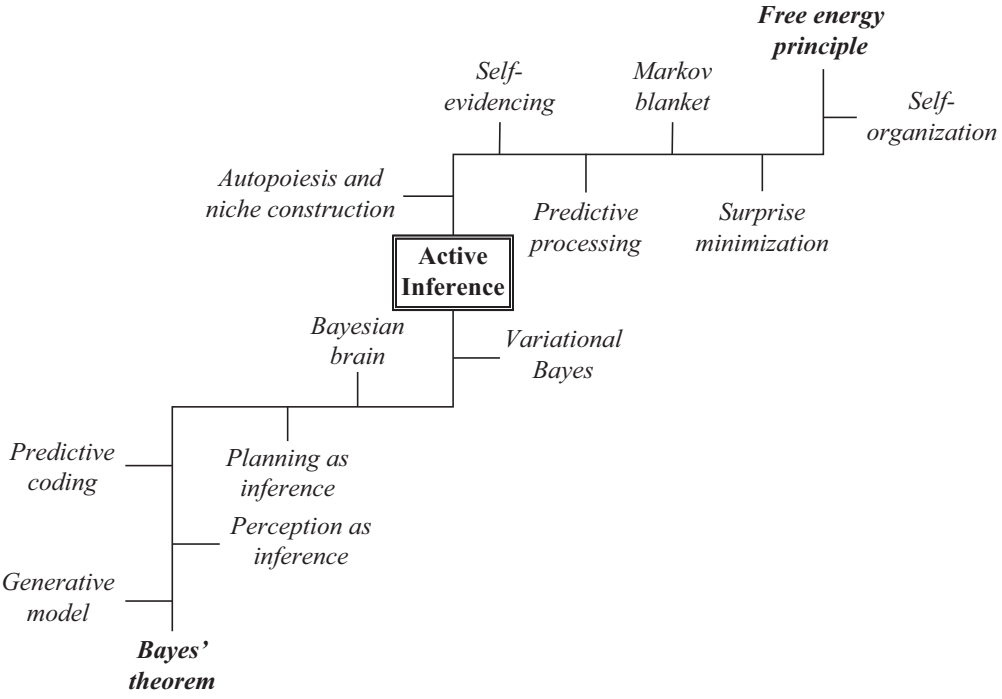


图 1.2: 通向主动推断的两条路径：高路径（从右上角出发）与低路径（从左下角出发）. 图内术语的中文对照见正文后的词表.

在第 2 章, 我们阐述主动推断的低路径视角. 我们从将知觉视为统计（贝叶斯）推断问题的基础理论（Helmholtz 1866), 以及它们的现代表现形式——贝叶斯脑假说（Doya 2007）出发. 我们将看到，为了进行这种（知觉）推断，生物体必须具备或体现一个关于其感觉观测如何产生的概率生成模型. 这一模型对可观测变量（感觉观测）和不可观测（隐）变量的信念（概率分布）进行编码. 我们将把这种推断视角从知觉推广到行动选择、规划和学习问题.

在第 3 章，我们将介绍与之互补的主动推断高路径视角. 本章引入自由能原理以及生物体必须最小化惊异的命令. 进一步地，本章阐明这一原理如何涵盖自组织动力学，以及如何维持使生物体与环境分离的统计边界，即马尔可夫毯. 这对于维持生物体的完整性至关重要，也是其自创生的核心.

在第 4 章，我们将更形式化地阐明主动推断. 本章以第 2 章关于贝叶斯脑的讨论为起点，给出第 3 章的自我证成动力学与变分推断之间的数学关系. 此外，本章介绍用于构造主动推断问题的两类生成模型，包括用于决策和规划的部分可观测马尔可夫决策过程，以及与感觉受体和肌肉相接的连续时间动力学模型. 最后，我们将看到，对每类模型而言，自由能最小化如何表现为动态信念更新.

在第 5 章，我们从形式处理转向主动推断的生物学含义. 我们以 “大脑中发生变化的一切都必须最小化自由能”（Friston 2009）为前提出发，讨论自由能最小化中涉及的具体量（例如预测、预测误差和精度信号）如何在神经元动力学中体现. 这有助于将主动推断的抽象计算原理对应到生理基质能够执行的具体神经计算. 这对于在该框架下提出假设很重要，并确保这些假设能够接受测量数据的检验. 换言之，第 5 章阐述与主动推断相关的过程理论.

在全书第一部分，我们将讨论主动推断的几个特征方面. 它们突出了主动推断与其他试图解释生物调节和认知的框架之间的区别，其中一些在此预先介绍.

- 在主动推断中，知觉和行动是满足同一命令——自由能最小化——的两种互补方式. 知觉通过（贝叶斯）信念更新或改变想法来最小化自由能（及惊异），使信念与感觉观测相容. 行动则通过改变世界使其与信念和目标更加相容，从而最小化自由能（及惊异）. 这种认知功能的统一使主动推断与将行动和知觉孤立处理的其他方法有着根本区别. 学习是最小化自由能的另一种方式；但它与知觉并无根本区别，只是在较慢的时间尺度上运作. 第 2 章将阐明知觉与行动的互补性.

- 主动推断框架不仅驱动当前的行动选择以改变现有感觉数据，还包含规划，即选择未来最优的行动过程或策略. 这里的最优性相对于期望自由能来度量，与上文在行动和知觉的语境中所讨论的变分自由能不同. 计算变分自由能依赖当前和过去的观测，而计算期望自由能还需要预测未来的观测，因而称为“期望”. 一个策略的期望自由能由两部分组成：第一部分量化预计该策略能在多大程度上消解不确定性（探索），第二部分量化预测结果与智能体目标的一致程度（利用）. 与其他框架不同，主动推断中的策略选择会自动平衡探索和利用. 第 2 章将阐明变分自由能与期望自由能的关系.

- 在主动推断中，所有认知操作都被构想为对生成模型进行推断，这与大脑进行概率计算的观点，即贝叶斯脑假说，一致. 然而，诉诸贝叶斯推断的一种特定近似形式，即由第一性原理引出的变分方案，使过程理论更为具体. 此外，主动推断将推断方法扩展到很少被考虑的认知领域，并对生物大脑可能实现的模型及推断过程作出更具体的限定. 在某些假设下，主动推断所用生成模型产生的动力学与计算神经科学中的广泛使用的模型密切对应，例如预测编码（Rao and Ballard 1999）和 Helmholtz 机（Dayan et al. 1995）. 第 4 章将阐明变分方案的具体细节.

- 在主动推断中，知觉和学习都是主动过程，理由有二. 首先，大脑本质上是一台预测机器，不断预测传入刺激，而不是被动地等待刺激. 这一点很重要，因为知觉和学习过程始终以先前预测为背景；例如，预期和未预期的刺激对知觉和学习的影响不同. 其次，进行主动推断的生物会主动寻找能够消解其不确定性的显著感觉观测，例如通过调整感觉器官的朝向或选择有信息量的学习片段. 知觉和学习的主动性与大多数将它们视为主要是被动过程的现代理论形成对比；第 2 章将对此加以阐明.

- 行动具有典型的目标导向性和目的性. 它以期望的结果或目标为起点，类似于控制论中的设定点概念，并将其编码为先验预测. 规划通过推断一个满足这一预测的行动序列来进行，或者等价地说，通过推断一个减少先验预测与当前状态之间预测误差的行动序列来进行. 主动推断中行动的目标导向性与早期控制论表述一致，但不同于大多数以刺激—反应映射或状态—行动策略解释行为的现代理论. 刺激—反应行为或习惯性行为因此成为主动推断中更广泛的一类策略的特例. 第 2、3 章将阐明主动推断的目标导向性.

- 主动推断的各种构念在大脑中都有合理的生物学对应物. 这意味着，一旦针对所研究的问题定义了一个具体的生成模型，就可以从作为规范理论的主动推断转向作为过程理论的主动推断，从而作出具体的经验预测. 例如，知觉推断和学习分别对应突触活动的变化和突触效能的变化；预测编码中预测的精度对应预测误差单元的突触增益；策略的精度对应多巴胺能活动. 第 5 章将阐明主动推断的部分生物学后果.

1.4.2 第二部分：主动推断的实践

本书第一部分为读者提供理解主动推断的概念和形式工具，第二部分则着重于实践问题. 具体而言，我们希望提供工具，使读者能够理解认知功能（及功能障碍）的现有主动推断模型，并设计新模型. 为此，我们讨论采用主动推断的具体模型实例. 值得注意的是，主动推断模型可以沿不同维度变化，例如采用离散或连续时间表述、平坦或层级推断. 第二部分的结构如下.

第 6 章介绍构建主动推断模型的步骤. 这些步骤涵盖设计有效模型所需的要点，包括确定所关注的系统、最合适的生成模型形式（例如用于刻画离散或连续时间现象），以及模型中需要包含的具体变量. 因此，本章介绍了支撑后续章节模型的设计原则.

第 7 章讨论处理离散时间问题的主动推断模型，例如将问题表述为隐马尔可夫模型（HMM）或部分可观测马尔可夫决策过程（POMDP）. 我们的例子包括知觉处理模型和离散觅食选择模型，即在决策点向左还是向右转以获得奖励. 我们还介绍信息寻求、学习和新奇寻求等可用离散时间主动推断处理的主题.

第 8 章讨论采用随机微分方程处理连续时间问题的主动推断模型，包括知觉模型（如预测编码）、运动控制模型和序列动力学模型. 有趣的是，主动推断的一些最有特色的预测出现在连续时间表述中，例如运动生成源自预测的实现，以及注意现象可以用精度控制来理解. 我们还介绍同时包含离散和连续时间变量的主动推断混合模型. 这些模型允许同时评估离散选项之间的选择（例如扫视的目标）及其产生的连续运动（例如眼球运动）.

第 9 章说明如何使用主动推断模型分析行为实验数据. 我们讨论基于模型的数据分析所需的具体步骤，从数据收集到模型构建及其反演，以支持对单个参与者或群体层面数据的分析.

第 10 章讨论主动推断与心理学、神经科学、人工智能和哲学中其他理论的关系，并突出主动推断区别于其他理论的最重要方面.

在附录中，我们简要讨论理解本书技术性最强的部分所需的数学背景，包括泰勒级数近似、变分拉普拉斯方法、变分法等概念. 为便于参考，我们还以简明形式列出主动推断中使用的最重要方程.

总之，第二部分展示了使用主动推断构建的多种生物和认知现象模型，以及设计新模型的方法. 除了具体模型本身的意义外，我们希望本书的讨论能够阐明使用统一的规范性框架、从一致的视角研究生物和认知现象的价值. 归根结底，这正是规范性框架真正的吸引力：提供统一视角和指导原则，以协调表面上互不相关的现象；在这里，这些现象包括知觉、决策、注意、学习和运动控制，它们在任何心理学或神经科学教材中各有独立章节.

第二部分重点介绍的模型经过挑选，旨在尽可能简单地说明具体问题. 尽管我们涉及从离散时间决策到连续时间知觉与运动控制的多个模型和领域，显然仍忽略了许多同样有趣的内容. 文献中还有许多其他主动推断模型，涉及生物自组织与生命起源（Friston 2013）、形态发生（Friston, Levin et al. 2015）、认知机器人学（Pio-Lopez et al. 2016, Sancaktar et al. 2020）、社会动力学与生态位构建（Bruineberg, Rietveld et al. 2018）、突触网络动力学（Palacios, Isomura et al. 2019）、生物网络中的学习（Friston and Herreros 2016），以及创伤后应激障碍（Linson et al. 2020）和恐慌障碍（Maisto, Barca et al. 2021）等精神病理状况. 这些模型沿许多维度变化：有些与生物学的联系更直接，另一些则较间接；有些是单智能体模型，另一些是多智能体模型；有些研究适应性推断，另一些研究适应不良的推断，例如患者群体中的推断，等等.

这些日益增多的文献表明主动推断越来越受到关注，也表明它可以用于种类繁多的领域. 本书旨在使读者能够理解主动推断，并在自己的研究中运用它，也许还能探索其尚未预见的潜力.

Free energy principle：自由能原理；Self-organization：自组织；Markov blanket：马尔可夫毯；Self-evidencing：自我证成；Surprise minimization：惊异最小化；Predictive processing：预测加工；Autopoiesis and niche construction：自创生与生态位构建；Active Inference：主动推断；Bayesian brain：贝叶斯脑；Variational Bayes：变分贝叶斯；Predictive coding：预测编码；Planning as inference：作为推断的规划；Perception as inference：作为推断的知觉；Generative model：生成模型；Bayes' theorem：贝叶斯定理.

1.5 小结

本章从规范性视角简要介绍了主动推断如何解释生物学问题，并预告了这一视角的一些含义，后续章节将进一步展开. 此外，本章说明了全书分为两部分，分别旨在帮助读者理解主动推断，以及将其用于自己的研究. 接下来的几章将发展这里概述的低路径与高路径视角，然后深入讨论生成模型的结构及其产生的消息传递. 它们共同构成主动推断的原理，并为主动推断的实践提供预备知识. 我们希望这些章节能够使读者相信，主动推断不仅提供了理解行为的统一原理，也提供了一种切实可行的方法，用于研究自主系统中的行动与知觉.

Chapter 2

通向主动推断的低路径

我的思想从始至终、永远都是为了我的行动.
—William James

2.1 引言

本章从赫尔姆霍茨式（或许也可称为康德式）的 “知觉是无意识推断”（Helmholtz 1867）这一观点出发，引入主动推断，并介绍近年来在贝叶斯脑假说下出现的相关思想. 本章解释主动推断如何通过将知觉、行动、规划和学习都视为（贝叶斯）推断问题，将这些思想纳入并加以扩展；同时，主动推断针对这些原本难以求解的问题推导出有原理依据的（变分）近似.

2.2 作为推断的知觉

将大脑视为 “预测机器”，即推断和预测外部世界状态的统计器官，具有悠久的传统. 这一思想可追溯至 “知觉是无意识推断” 的观念（Helmholtz 1866）. 近年来，它被重新表述为 “贝叶斯脑” 假说（Doya 2007）. 从这一视角看，知觉并非单纯地自下而上将感觉状态（例如视网膜上的状态）转换为对外部世界的内部表征（例如神经元活动模式）. 相反，知觉是一个推断过程，将关于感觉最可能成因的（自上而下的）先验信息与（自下而上的）感觉刺激结合起来. 推断过程作用于世界状态的概率表征，并遵循贝叶斯规则；该规则规定了根据感觉证据进行的（最优）更新. 知觉并非被动的、由外向内的过程，即从 “外部” 事物在感觉上皮上留下的印迹中提取信息；它是一个建构性的、由内向外的过程，即利用感觉来证实或否定关于感觉如何产生的假设（MacKay 1956, Gregory 1980, Yuille and Kersten 2006, Neisser 2014, A. Clark 2015）.

进一步说，进行贝叶斯推断需要一个生成模型，有时也称为前向模型. 生成模型是统计理论中的一种构造，用于生成关于观测的预测. 它可以表述为观测 y 与产生这些观测的世界的隐状态 x 的联合概率 $P(y, x)$. 后者被称为隐状态或潜在状态，因为它们不能被直接观测. 这一联合概率可以分解为两部分. 第一部分是先验 $P(x)$，表示生物体在看到感觉数据之前关于世界隐状态的知识. 第二部分是似然 $P(y \mid x)$，表示生物体关于观测如何由状态产生的知识. 贝叶斯规则告诉我们如何组合这两个要素：本质上，它将先验概率 $P(x)$ 更新为接收观测后隐状态的后验概率 $P(x \mid y)$. 需要简要温习基础概率论的读者可参见框 2.1.

框 2.1：概率的求和法则与乘积法则

概率推理以两个关键法则为基础，即概率的求和法则和乘积法则，分别如下：

$$\sum_x P(x) = 1,$$
$$P(x)P(y \mid x) = P(x, y).$$

求和法则指出，所有可能事件 x 的概率之和（或积分）必须为 1. 乘积法则指出，两个随机变量 x 和 y 的联合概率可以分解为一个变量的概率 $P(x)$ 与给定第一个变量时第二个变量的条件概率 $P(y \mid x)$ 的乘积. 条件概率是在已知一个变量（此处为 x）取值的情况下，另一个变量（此处为 y）的概率.

由这些简单法则可以得到两个重要结果：边缘化运算和贝叶斯规则. 边缘化使我们能够从联合分布中得到两个变量中单个变量的分布：

$$\underbrace{\sum_x P(x, y) = \sum_x P(y)P(x \mid y)}_{\text{乘积法则}} = \underbrace{P(y) \sum_x P(x \mid y) = P(y)}_{\text{求和法则}}.$$

y 的概率称为边缘概率，而这一运算称为将 x 边缘化. 贝叶斯规则可直接从乘积法则得到：

$$\underbrace{P(x)P(y \mid x)}_{\text{乘积法则}} = P(x, y) = \underbrace{P(y)P(x \mid y)}_{\text{乘积法则}}.$$

这使我们能够在先验和条件分布（似然）与相应的边缘分布和另一个条件分布（后验）之间转换. 简单地说，贝叶斯规则表明，两个事物的联合概率等于给定第二个事物时第一个事物的概率乘以第二个事物的概率，也等于给定第一个事物时第二个事物的概率乘以第一个事物的概率.

贝叶斯推断是一个广泛的主题，出现在统计学、机器学习和计算神经科学等学科中. 全面讨论相关主题超出了本书范围，但有意深入了解的读者可以参考优秀的资料（Murphy 2012）. 不过，这一切都建立在一条简单规则之上. 为说明这条规则，我们考虑一个贝叶斯知觉推断的例子（图 2.1）. 设想一个人坚信面前是一个苹果. 这一信念对应一个先验概率，简称先验. 该先验包括赋予苹果假设的概率和赋予其他假设的概率. 在这个例子中，备选假设是面前的东西不是苹果，而是青蛙. 从数值上说，先验概率分布为苹果赋值 0.9，为青蛙赋值 0.1. 注意，由于假设只有这两个合理且互斥的可能性，它们的概率之和必须为 1. 这个人还具有一个似然模型：该模型对青蛙会跳而苹果不会跳赋予较高的概率. 这一似然给出了两个隐状态（青蛙或苹果）到两个观测（跳或不跳）的概率映射. 先验和似然共同构成这个人的生成模型.

现在假设此人观察到她的苹果—青蛙跳了起来. 贝叶斯规则告诉我们如何考虑跳跃的似然，从先验形成后验信念. 这一规则表示为

$$P(x \mid y) = \frac{P(x)P(y \mid x)}{P(y)}. \tag{2.1}$$

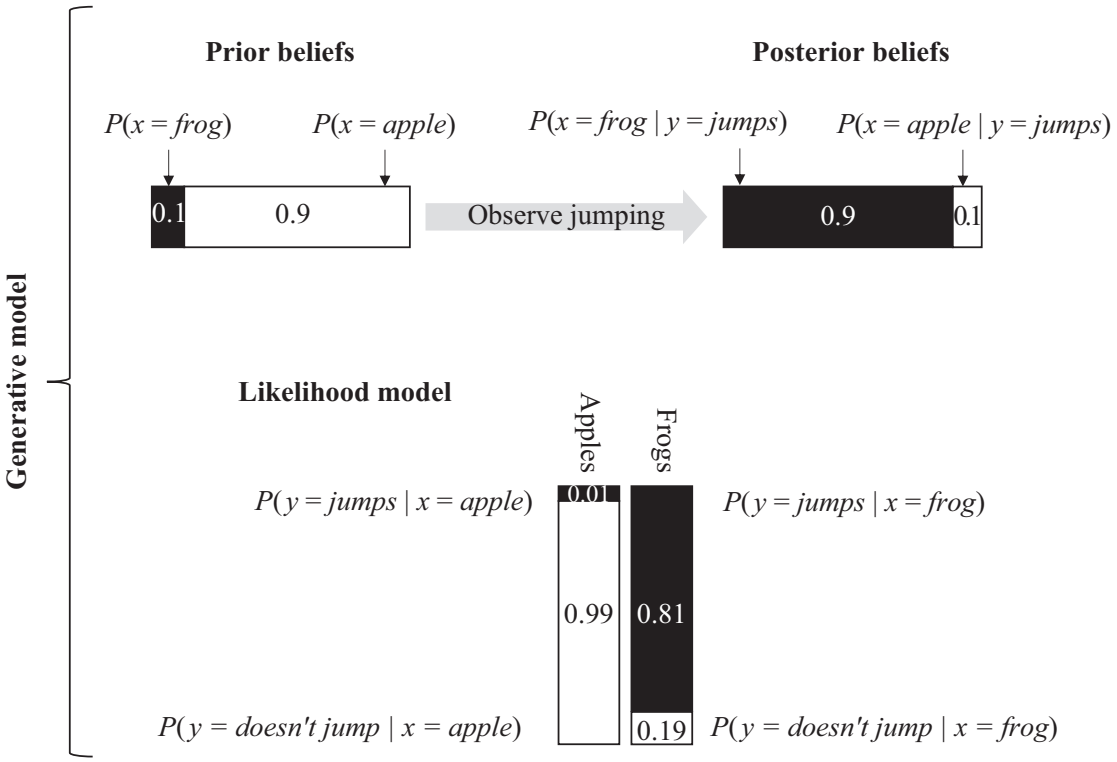


图 2.1: 贝叶斯推断的一个简单例子. 左上: 生物体在作出任何观测之前, 关于将要看到的物体的先验信念 $P(x)$, 即对苹果（概率 0.9）和青蛙（概率 0.1）这两种可能性的范畴分布. 右上: 观察到物体跳跃后, 生物体的后验信念 $P(x \mid y)$. 后验信念可在似然函数 $P(y \mid x)$ 下利用贝叶斯规则计算. 似然函数显示于先验和后验下方: 如果物体是苹果, 其跳跃的概率很小（0.01）; 如果是青蛙, 跳跃概率则高得多（0.81）. 图中的概率条并未严格按比例绘制. 在这个具体例子中, 从先验到后验的更新幅度很大. 图内 Prior beliefs、Posterior beliefs、Observe jumping、Generative model 和 Likelihood model 分别表示先验信念、后验信念、观察到跳跃、生成模型和似然模型; apple、frog、jumps 和 doesn't jump 分别表示苹果、青蛙、跳和不跳.

在图 2.1 的似然模型下，赋给青蛙的后验概率为 0.9，赋给苹果的后验概率为 0.1. 如框 2.1 所强调的，式 (2.1) 的分母可以通过将分子边缘化来计算. 借助苹果—青蛙的例子，我们来阐明两种不同的惊异概念；两者对主动推断都很重要. 第一种被我们简称为惊异，是负对数证据，其中证据是观测的边缘概率. 在我们的例子中，这就是在生成模型下观察到任何东西跳跃的概率的负对数. 从贝叶斯视角看，惊异是一个非常重要的量：它度量模型对其试图解释的数据拟合得有多差. 为了直观说明这一点，我们可以计算在模型下观察到跳跃行为的概率. 请记住，模型为苹果赋予非常高的先验概率，为青蛙赋予很低的先验概率. 因此，跳跃的边缘概率如下：

$$\begin{aligned} P(y = \text{跳}) &= \sum_x P(x, y = \text{跳}) \\ &= \sum_x P(x) P(y = \text{跳} \mid x) \\ &= P(x = \text{青蛙}) P(y = \text{跳} \mid x = \text{青蛙}) \\ &\quad + P(x = \text{苹果}) P(y = \text{跳} \mid x = \text{苹果}) \\ &= 0.1 \times 0.81 + 0.9 \times 0.01 \\ &= 0.09. \end{aligned} \tag{2.2}$$

这意味着，在这一模型下，100 次观测中预计只有约 9 次会观察到跳跃行为. 因此，如果我们相信图 2.1 的模型，那么观察到跳跃就会感到惊异. 可以用惊异量 $\mathfrak{I}$ 来量化这一点：$\mathfrak{I}(y = \text{跳}) = -\ln P(y = \text{跳}) = -\ln(0.09) = 2.4$ 奈特[1]. 这个数值越大，模型对当前观测的解释就越不恰当. 这使我们能够相对于数据比较模型. 例如，考虑另一个模型，其中我们的先验信念是每次看到的都是青蛙. 按照式 (2.2) 相同的步骤计算，惊异约为 0.2 奈特. 这是对这些数据更好的模型，因为该观测的惊异程度小得多. 按证据（或惊异）对模型打分的过程通常称为贝叶斯模型比较. 对更复杂的模型而言，惊异的形式可能不这么简单. 除了本例中的范畴概率，表 2.1 还给出一系列概率分布的惊异形式（省略常数）. 关键在于，这使我们能够讨论支撑集[2]不同于本例的概率分布的惊异. 这很重要，因为世界产生感觉数据的方式随数据种类而变化. 我们可能因看到一张没有预期会看到的脸而惊异（范畴分布），也可能因室外比预期更冷而惊异（连续分布）. 表 2.1 可视为后续章节构建生成模型时可以选用的概率分布集. 更一般地说，这一表格说明，对于任何给定的概率分布族都可以计算惊异.

第二种惊异概念被称作贝叶斯惊异，这一名称略有些令人困惑. 它度量一次观测之后我们需要更新信念的程度. 换言之，贝叶斯惊异量化先验概率与后验概率之间的差异. 这引出一个问题：如何量化两个概率分布的不相似程度？信息论给出的一个答案是使用 Kullback–Leibler（KL）散度，其定义为两个对数概率之差的平均值：

$$D_{\mathrm{KL}}[Q(x) \| P(x)] \triangleq \mathbb{E}_{Q(x)}[\ln Q(x) - \ln P(x)]. \tag{2.3}$$

这里的 $\mathbb{E}$ 符号表示平均值或期望，如框 2.2 所述. 利用 KL 散度，可以量化本例中的贝

表 2.1: 概率分布与惊异[3]

分布	支撑集	惊异 $\mathfrak{I}$
高斯分布	$x \in \mathbb{R}$	$\frac{1}{2}(x-\mu)\cdot\Pi(x-\mu)$
多项分布 [1]	$x_i \in (0,\dots,N)$ $i \in \{1,\dots,K\}$ $\sum_i x_i = N$ $x_i \in (0,1)$	$-\sum_i x_i \ln d_i$
狄利克雷分布 [2]	$i \in \{1,\dots,K\}$ $\sum_i x_i = 1$	$\sum_i (1-\alpha_i)\ln x_i$
伽马分布	$x \in (0,\infty)$	$bx + (1-a)\ln x$

注：1. 特例包括范畴分布（$K>2, N=1$）、二项分布（$K=2, N>1$）和伯努利分布（$K=2, N=1$）. 2. 特例为贝塔分布（$K=2$）.

叶斯惊异：

$$
\begin{aligned}
&D_{\mathrm{KL}}[P(x \mid y)\|P(x)] \\
&= P(x=\text{青蛙} \mid y=\text{跳})\big(\ln P(x=\text{青蛙} \mid y=\text{跳}) - \ln P(x=\text{青蛙})\big) \\
&\quad + P(x=\text{苹果} \mid y=\text{跳})\big(\ln P(x=\text{苹果} \mid y=\text{跳}) - \ln P(x=\text{苹果})\big) \\
&= 0.9\big(\ln(0.9) - \ln(0.1)\big) + 0.1\big(\ln(0.1) - \ln(0.9)\big) \\
&\approx 1.8 \text{ 奈特}.
\end{aligned} \tag{2.4}
$$

这衡量的是信念更新的幅度，而不只是观测有多不可能发生. 为突出惊异与贝叶斯惊异的区别，考虑我们坚信总是会看到苹果时会发生什么. 贝叶斯惊异将为零，因为先验如此确定，以至于观测后我们完全不更新它. 然而，惊异非常大，为 4.6 奈特，因为苹果跳跃极不可能.

框 2.2：期望

讨论随机变量 x 的期望通常很有用，它一般记作 $\mathbb{E}[x]$. 这是该变量所有可能取值的加权平均，权重为各取值的概率. 对只能取可数个可能值的离散随机变量，这由加权和给出：

$$\mathbb{E}[x] = \sum_x xP(x).$$

例如, 对一个只能取数值 1 和 2, 且各自概率均为 $\frac{1}{2}$ 的离散变量, 有 $\mathbb{E}[x] = 1\cdot\frac{1}{2} + 2\cdot\frac{1}{2} = \frac{3}{2}$. 对可以取无穷多个值的连续随机变量，求和被积分取代. 期望也可作用于随机变量的函数，而不只是变量本身. 例如，若有函数 $f(x)$，其中 x 服从某个连续分布，则期望定义为

$$\mathbb{E}[f(x)] = \int f(x)p(x)\,dx.$$

全书都将使用这一记号，其中 $f(x)$ 常为对数概率或对数概率比.

注意，虽然我们用一个非常简单的生成模型说明了贝叶斯推断，但它适用于任何复杂程度的生成模型. 第 4 章将重点介绍支撑大多数主动推断应用的两种生成模型形式.

2.3 生物推断与最优性

上述推断方案与关于知觉的生物学和心理学理论之间有两个重要联系. 第一，所讨论的推断过程需要对预测（来自先验）进行编码的自上而下过程与对感觉观测（由似然介导）进行编码的自下而上过程相互作用. 这种相互作用使推断视角区别于只考虑自下而上过程的其他方法. 此外，它也是现代理解知觉的生物学研究的核心，例如预测编码（第 4 章讨论），即这里所讨论的更一般的（贝叶斯）推断方案在算法或过程层面的一种具体实现.

第二，贝叶斯推断是最优的. 最优性相对于被优化（即最小化）的代价函数来定义；对于贝叶斯推断，这一代价函数称为变分自由能，它与惊异密切相关. 我们将在第 2.5 节回到这一点. 由于显式考虑了隐状态上的完整分布，贝叶斯推断自然能够处理不确定性，从而避免仅考虑隐状态点估计（例如 x 的平均值）的其他方法的局限. 最大似然估计就是这类方法之一，它只选择最有可能产生当前数据的隐状态. 其问题在于，这种估计忽略了隐状态的先验合理性以及估计的不确定性. 贝叶斯推断没有这些局限. 然而，尽管惊异可用于客观评估模型是否适用于其目的，我们仍需认识到推断本身是主观的. 推断结果不一定在任何客观意义上都是准确的，即生物体的信念可能实际上并不符合现实. 这至少有两个重要原因. 第一，生物的计算和能量资源有限，使精确的贝叶斯推断难以求解[4]. 因此需要近似，而近似使精确贝叶斯最优性无法得到保证. 这些近似包括基于所谓平均场近似的变分后验概念，它是第 4 章的核心内容.

最优性可能被视为主观的第二个原因是，生物体依据主体对其观测如何产生的生成模型运作，而这个模型可能与实际产生观测的真实生成过程相符，也可能不符. 这并不是说生成模型应该与生成过程相符. 事实上，某些模型对当前数据所作的解释可能比实际产生这些数据的过程更好，例如更简单；这种优劣可由它们的相对惊异量化. 错觉是一个很好的例子：相较于一位爱恶作剧的心理物理学家精心设计视觉刺激的实际方式，人们对自己的视觉输入找到了更简单的解释.

随着新经验的获得，生成模型本身可以得到优化；它可能收敛到生成过程，也可能不会. 图 2.2 说明了这一点，以及真实的环境相依关系，即生物体无法直接获得的生成过程，与生物体关于世界的生成模型之间的区别.

在这一具体例子中，生成过程处于生物体无法直接获得的真实状态 x^*. 然而，生物体与世界相互耦合，x^* 产生一个观测 y，由生物体感知. 生物体可以利用观测 y 和贝叶斯规则，推断生成模型中某个解释变量或隐状态的后验概率. 在图中，我们将 x^* 和 x 都称为隐状态，以强调二者都不可观测. 但二者存在细微差别：前者是生物体生成模型的一部分，后者是生成过程的一部分，无法为生物体直接获得.[1] 此外，x^* 和 x 不一定处于同一个空间. 外部世界中的隐状态可能取大脑可用解释空间之外的值；反过来，大脑的解释也可能包括外部世界中不存在的变量. 例如，前者可能是五维的，而后者是二

[1]译注：原文此句中 “前者” 和 “后者” 的归属与紧接其前的 x^*、x 次序以及图和图注不一致；此处保留原文，待查勘误.

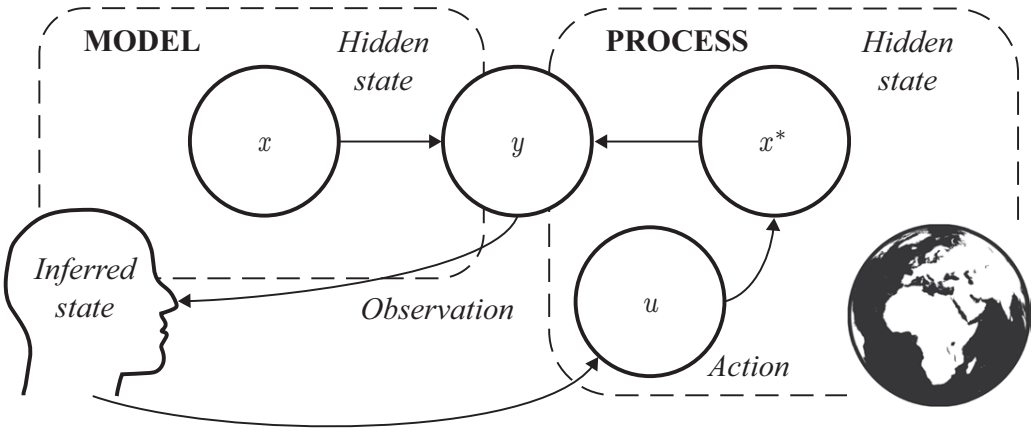


图 2.2: 生成过程与生成模型. 二者都表示给定隐状态 x 时可能产生感觉数据 y 的方式，图中用从 x 指向 y 的箭头表示因果关系. 区别在于，过程是数据产生的真实因果结构，而模型是用于推断数据成因的构造，即利用观测推导推断状态. 生成模型和生成过程的隐状态并不相同. 生物体的模型包含关于隐状态的一系列假设 x，其中不一定包含生成过程隐状态的真实值 x^*. 换言之，我们用来解释感觉世界的模型可能包含外部世界中不存在的隐状态，反之亦然. 行动 u 根据生成模型下作出的推断而产生. 尽管行动由模型下的推断选出，这里仍将其显示为生成过程的一部分，它会改变世界. 图中 MODEL、PROCESS、Hidden state、Inferred state、Observation 和 Action 分别表示模型、过程、隐状态、推断状态、观测和行动.

维的；或者一个是连续的，另一个是范畴型的.

生成模型与生成过程的区别对于理解心理学中有关推断最优性的论断很重要，即便这些论断有效，在贝叶斯视角下其有效性也总是以生物体的资源为条件. 这里的资源指生物体特定的生成模型，以及有限的计算和记忆资源.

2.4 作为推断的行动

到目前为止的讨论是所有贝叶斯脑理论共有的. 现在我们引入主动推断提供的简单而根本的进展：从上述相同的推断视角出发，将其扩展到把行动也视为推断. 这一思想源于贝叶斯推断最小化惊异（或者等价地，最大化贝叶斯模型证据）的概念. 到目前为止，我们考虑的是进行推断并计算惊异时会发生什么，以及如何依据模型最小化惊异的能力在模型之间作出选择. 然而，惊异不仅取决于模型，也取决于数据. 通过作用于世界以改变数据产生的方式，我们可以选择在模型下惊异最小的数据，确保模型适用于其目的.

拥有产生行动的机制后，生物体便可以与环境进行相互交换，见图 2.2. 对动物而言，这种机制采取运动反射环路的形式. 基本上，在每一次行动—知觉循环中，环境向生物体发送一个观测；生物体利用贝叶斯推断（的一种近似）推断最可能的隐状态；接着产生一个行动并将其发送到环境，试图使环境的惊异程度降低；环境执行该行动，产生一个新观测并将其发送给生物体；然后新的循环开始. 这里按顺序描述是出于教学目的；必须认识到，这些实际上不是离散的步骤，而是连续的动力学过程.

主动推断并不止于认识到知觉和行动具有相同的推断性质. 它还假设，知觉和行动相互协作以实现同一个目标，或只优化一个函数，而不像通常所假设的那样具有两个不同的目标. 在主动推断文献中，这个共同目标以各种非形式和形式的方式表述，包括最小化惊异、熵、不确定性、预测误差或（变分）自由能. 这些术语彼此相关，但它们之间的关系有时并不显然，因此会造成一些混淆. 此外，这些术语用于不同的语境；例如，最小化预测误差用于旨在解释大脑信号的生物学语境，而最小化变分自由能用于机器学习.

在接下来的两节中，我们将阐明主动推断智能体通过知觉和行动最小化的单一量是变分自由能. 然而，在某些条件下，变分自由能可以化约为其他概念，例如生成模型与世界之间的差异，或预期与观测之间的差异，即预测误差. 我们将在第 2.5 节形式化地引入变分自由能. 为简单起见，第 2.4 节着重于知觉和行动最小化生成模型与世界之间差异的方式.

2.5 最小化模型与世界之间的差异

既然已经用贝叶斯推断解释了知觉和行动，我们转而讨论推断的目标是什么，换言之，推断优化的是什么. 在认知科学中，人们常假设知觉和行动等不同认知功能优化不同目标. 例如，我们可以假设知觉最大化重构的准确性，而行动选择最大化效用. 相比之下，主动推断的一个根本见解是，知觉和行动服务于完全相同的目标. 作为第一近似，这一共同目标可以表述为最小化模型与世界之间的差异；有时，这通过预测误差来操作化.

为理解知觉和行动如何减少模型与世界之间的差异，再考虑一个预期看到苹果的人（图 2.3）. 她自上而下地产生一个视觉预测，例如看到某种红色且不跳跃的东西. 将这一视觉预测与一种感觉（例如某物正在跳跃）相比，就会产生差异.

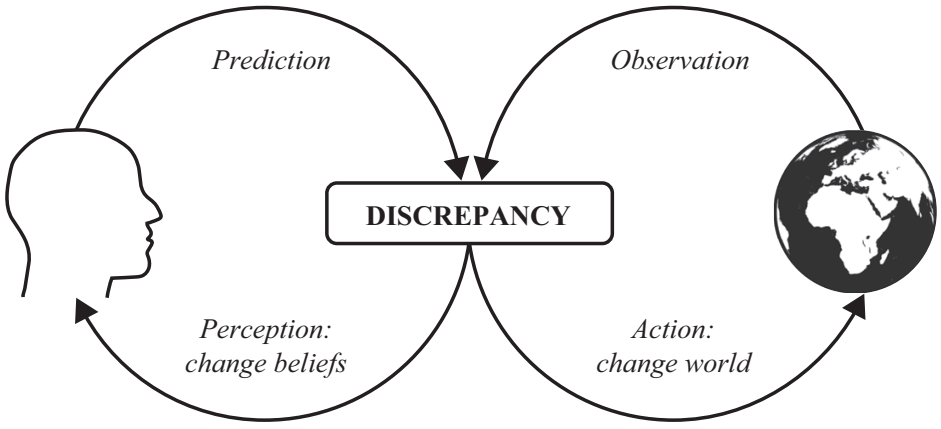


图 2.3: 知觉和行动都使模型与世界之间的差异最小化. 图中 Prediction、Observation、Discrepancy 分别表示预测、观测、差异；Perception: change beliefs 表示知觉：改变信念；Action: change world 表示行动：改变世界.

这个人可以用两种方式消除差异. 第一，她可以改变对于所见事物的想法，即认为它是青蛙，使想法符合世界，从而消除差异；这对应知觉. 第二，她可以把最近的苹果树

移至中央视野，看到一个非常像苹果的东西. 这也消除了最初的差异，但方式不同：她改变世界，包括自己的注视方向，以及随后的感觉，使其符合心中的想法，而不是改变想法以符合世界. 这是另一种拟合方向，即行动.

在苹果与青蛙的例子中，改变注视方向似乎不如改变想法令人信服. 再考虑另一种情形：一个人预期其体温处于某一范围，却通过中枢温度感受器感受到高温. 这令人惊异，并造成一个有待消除的显著差异. 如同前例，他有两种方式最小化差异，分别对应知觉（改变想法）和行动（改变世界）. 在这种情况下，仅仅改变想法似乎不太适应，而采取行动降低体温，例如打开窗户，则是适应性的.

这说明，在主动推断中，边缘概率或惊异的概念（例如关于体温的惊异）具有超越标准贝叶斯处理的意义，涵盖稳态和异稳态设定点等观念. 从技术上说，主动推断智能体具有这样的模型：它为智能体偏好进入的状态或偏好获得的观测赋予较高的边缘概率. 对鱼而言，这意味着处于水中具有较高的边缘似然. 这意味着生物体隐含地预期自己采样的观测会处在舒适区域内，例如生理界限之内.

总之，我们讨论了如何在任何时刻通过知觉和行动最小化模型与世界之间的差异. 我们调整信念还是数据，取决于持有这些信念的置信程度. 在苹果的例子中，对该信念的不确定性足够大，使其会被更新，而不是据此行动. 相比之下，在体温的例子中，由于核心体温支撑着我们的存在，我们对其有更高的置信度；这种置信度意味着我们改变世界以符合信念. 然而，在主动推断中，知觉与行动之间的协作比这种讨论所暗示的更紧密. 为理解其原因，下一节从差异或预测误差这一受限概念转向更一般的变分自由能概念：这是主动推断实际最小化的量，并把预测误差作为一个特例包含在内.

2.6 最小化变分自由能

到目前为止，我们在一个旨在最小化惊异的贝叶斯方案中讨论了知觉和行动. 然而，支持知觉和行动的精确贝叶斯推断在大多数情况下计算上难以处理，因为模型证据 $P(y)$ 和后验概率 $P(x \mid y)$ 这两个量可能由于以下两个原因无法计算. 第一，对复杂模型而言，可能存在许多类型的隐状态，全部都需要边缘化，使问题在计算上难以处理. 第二，边缘化运算可能需要在解析上难以求解的积分. 主动推断采用一种可处理的贝叶斯推断变分近似.

变分推断的形式体系将在第 4 章阐明. 此处只需指出，进行变分贝叶斯推断意味着将两个难以处理的量——后验概率和（对数）模型证据——分别替换为两个近似它们、但能高效计算的量，即近似后验 Q 和变分自由能 F. 近似后验有时称为变分分布或识别分布. 负的变分自由能也称证据下界（ELBO），尤其是在机器学习中.

最重要的是，贝叶斯推断问题现在成为一个优化问题：最小化变分自由能 F. 变分自由能根植于统计物理，在主动推断中起着根本作用. 式 (2.5) 中它记作 $F[Q, y]$，因为

它是近似后验 Q 的泛函（函数的函数），也是数据 y 的函数：

$$\begin{aligned} F[Q,y] &= \underbrace{-\mathbb{E}_{Q(x)}[\ln P(y,x)]}_{\text{能量}} - \underbrace{H[Q(x)]}_{\text{熵}} \\ &= \underbrace{D_{\mathrm{KL}}[Q(x)\|P(x)]}_{\text{复杂度}} - \underbrace{\mathbb{E}_{Q(x)}[\ln P(y \mid x)]}_{\text{准确度}} \\ &= \underbrace{D_{\mathrm{KL}}[Q(x)\|P(x \mid y)]}_{\text{散度}} - \underbrace{\ln P(y)}_{\text{证据}}. \end{aligned} \tag{2.5}$$

变分自由能乍看似乎是个抽象概念，但当它分解为认知科学中更直观、更熟悉的量时，其性质及其在主动推断中的作用便清晰起来. 每种视角都为自由能最小化的含义提供有用的直觉. 我们在此简要概述这些直觉，因为它们在第二部分讨论实例时将变得重要.

式 (2.5) 第一行表明，相对于 Q 最小化自由能要求与生成模型保持一致（能量），同时保持较高的后验熵[5]. 后者意味着，在缺少数据或精确的先验信念时（两者只影响能量项），我们应当对世界隐状态采用最大不确定的信念，这与 Jaynes 的最大熵原理一致（Jaynes 1957）. 简言之，没有信息时我们应当保持不确定，即采用高熵信念. 能量一词来自统计物理. 具体地，在玻尔兹曼分布下，系统处于某种构型的平均对数概率与该构型的能量成反比；这个能量即将系统从基准构型移到该构型所需的能量.

第二行强调将自由能最小化解释为寻找对感觉数据的最佳解释：这一解释必须能够准确[7]地说明数据，同时是最简单、复杂度最低[6]的解释，可与奥卡姆剃刀相比较. 复杂度与准确度之间的权衡反复出现在多个领域，通常处于数据分析中模型比较的语境. 统计学有时采用模型证据的其他近似，例如贝叶斯信息准则或赤池信息准则. 当我们讨论如何在基于模型的数据分析中使用自由能进行模型比较，以及讨论结构学习和模型约简时，这一权衡将变得重要. 从认知视角看，推断具有最小复杂度的解释也很重要，因为可以假设，为容纳数据而更新已有知识（先验）会带来认知代价（Ortega and Braun 2013, Zénon et al. 2019）；因此，偏离先验最少的解释更可取.

按照这一观点，复杂度代价就是贝叶斯惊异. 换言之，“我改变想法” 的程度由先验和后验之间的散度量化. 这意味着对感觉的每一种准确解释都产生复杂度代价，而该代价衡量贝叶斯信念更新的程度. 因此，变分自由能衡量准确度与复杂度之间的差异.

最后一行将自由能表示为负对数证据的一个界（见图 2.4）. 如图左侧所示，自由能是负对数证据的上界，其界限差距是 Q 与能够进行精确而非变分推断时所得后验概率之间的散度. 右侧表明，随着散度减小，自由能趋近负对数证据（惊异）；如果近似后验 Q 与精确后验 $P(x \mid y)$ 一致，自由能便等于惊异. 这为知觉推断提供了形式上的动机：尽可能优化近似后验 Q 是降低自由能的一种方式.

式 (2.5) 最后一行表明，知觉推断并非最小化自由能的唯一方式. 我们也可以通过行动改变感觉数据，从而改变对数证据项. 从认知视角看，这一分解很有意思，因为最小化散度和最大化证据分别对应知觉与行动这两个互补的子目标，见图 2.5. 注意，如果用 $P(x \mid y)$ 替换 Q，上述表达式都成为刻画负对数证据的方式，从而推广至精确推断的情形.

总之，主动推断就是通过知觉和行动最小化变分自由能. 这种最小化使生物体能够将生成模型与其采样的观测相拟合. 这种拟合既衡量知觉的适切性（由散度项表达），也

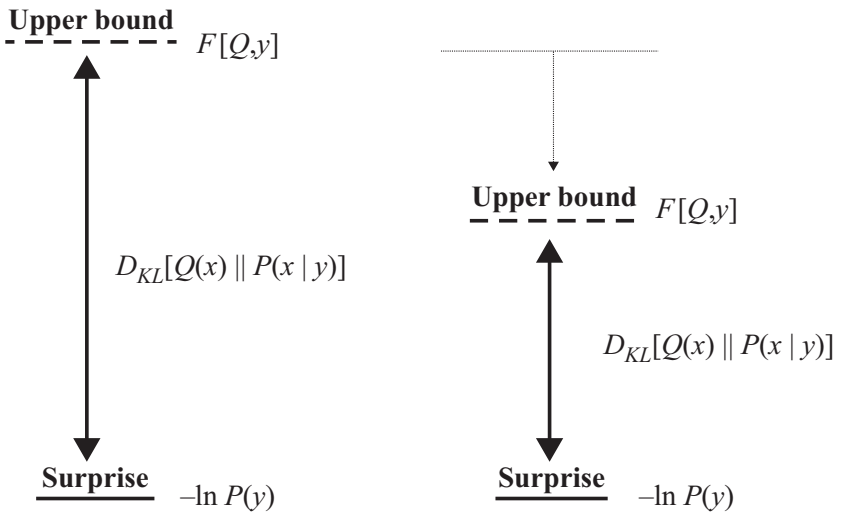


图 2.4: 变分自由能是负对数证据的上界. Upper bound 表示上界，Surprise 表示惊异.

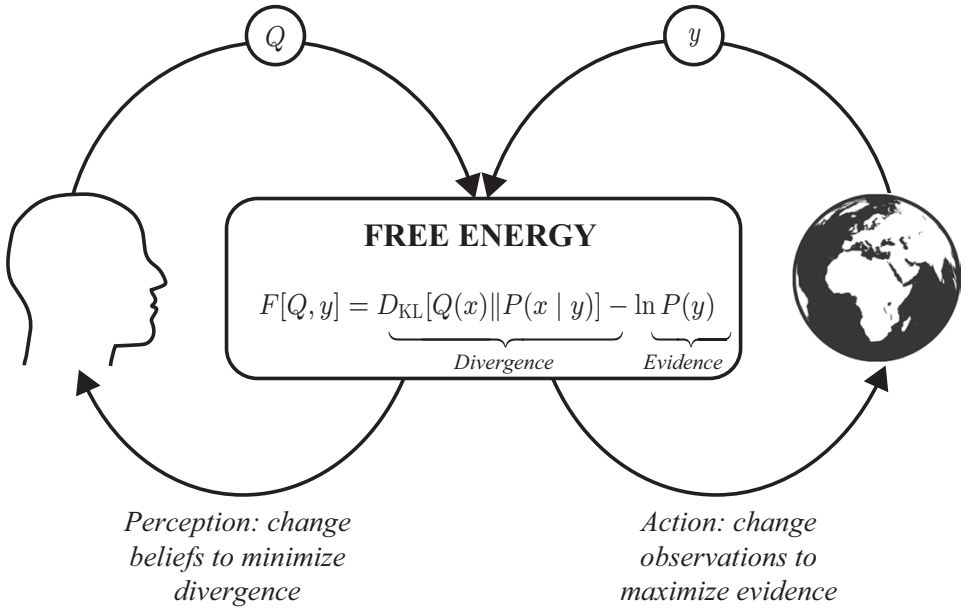


图 2.5: 知觉和行动在最小化变分自由能中的互补作用. 图中 Free energy、Divergence、Evidence 分别为自由能、散度和证据；左下为知觉：改变信念以最小化散度，右下为行动：改变观测以最大化证据.

衡量对外部状态的主动控制：它使生物体能够将自身维持在生成模型所定义的一组合适的偏好状态中. 另一种说法是诉诸自由能的散度—证据分解. 将负对数证据等同于惊异，并注意到散度的最小可能值为零，我们便可看到自由能是惊异的上界，即它只能大于或等于惊异. 当生物体通过知觉最小化散度时，自由能便成为惊异的近似. 当生物体进一步通过行动改变所获得的观测，使之更接近先验预测时，它便最小化了惊异.

变分自由能具有回顾性，因为它是过去和当前观测的函数，而不是未来观测的函数. 尽管它有助于根据过去的数据推断未来，但不能直接支持根据预期未来数据进行的前瞻性推断. 这在规划和决策中很重要：我们根据行动或行动序列（策略）预计带来的未来观测，推断最佳行动或行动序列. 为此，需要在生成模型中补充期望自由能的概念.

2.7 期望自由能与作为推断的规划

期望自由能将主动推断扩展到包含一种典型的前瞻性认知形式：规划. 规划一个行动序列，例如逃离迷宫所需的一系列移动，要求考虑预计将获得的未来观测. 例如，可能的行动过程所带来的后果包括右转后看到死胡同，或连续三次左转后看到出口. 每一个可能的行动序列都称为一个策略. 这凸显了主动推断中对行动与策略所作的重要区分：前者直接影响外部世界，后者则是关于某种行为方式的假设. 这意味着主动推断将规划和决策视为对要做什么进行推断的过程. 这使规划明确地进入贝叶斯推断的范畴，也意味着我们必须像先前那样指定先验和似然（第 2.1 节）. 不过，备选项不再是青蛙和苹果，而是行为策略：例如，我看向池塘还是看向树的概率更大？本节首先简要讨论似然，即执行策略的后果，随后转向先验；期望自由能就在此发挥作用.

依赖策略的结果不能立即获得，因为它们处于未来，但可以通过连接生成模型的两个组成部分来预测. 第一部分是我们关于隐状态如何随策略变化的信念；我们将在第 4 章详细讨论. 目前，我们使用记号 $\tilde{x}$ 表示隐状态随时间变化的序列或轨迹，并将轨迹以生物体所执行的策略 π 为条件. 这意味着模型的动力学部分由 $P(\tilde{x} \mid \pi)$ 给出. 沿用前面的青蛙—苹果例子，策略可以是决定去池塘还是果园，这会改变遇到青蛙与遇到苹果的概率.

模型的第二部分是通常的似然分布，它描述在每个可能状态下应预期哪些观测，例如以青蛙或苹果为条件的跳或不跳. 通过结合这两个组成部分，生物体可以在内部使用其生成模型，对可能的行动或策略的后果运行 “如果……会怎样” 或反事实模拟，例如 “如果我去池塘会怎样？” 对状态进行边缘化，便得到策略的边缘似然或证据 $P(\tilde{y} \mid \pi)$，或该量的一个自由能近似. 换言之，知道策略如何影响状态转移，就能计算该策略下一个观测序列的似然. 如式 (2.1) 所示，需要将这一似然与先验概率结合，才能计算执行某一策略的后验概率.

主动推断将这一规划问题分解为两个连续操作：首先计算每个策略的得分，然后形成关于执行哪个策略的后验信念. 前一操作定义了关于所执行策略的先验信念：最好的策略概率高，最差的策略概率低. 在主动推断中，策略的优劣由与其相关的负期望自由能评分，正如模型拟合的优劣由该模型的负自由能评分一样. 策略的期望自由能 G 不同于变分自由能 F，因为计算前者需要考虑依赖策略的未来观测，而后者只考虑当前和过去的观测. 因此，计算期望自由能要使用生成模型预测每个策略若被执行，在某一规划时域内将产生哪些未来观测. 此外，由于策略展开于多个时间步，每个策略最终的期望

自由能度量必须对该策略的所有未来时间步进行累计.

每个策略的期望自由能可以通过取负转换为质量得分，并直接作为进行主动推断的智能体的先验. 这是因为，期望自由能与物理学中的势能概念一致，表达在对数概率空间中. 因此，将它转换为策略上的信念或概率分布，只需进行指数运算以消去对数，并进行归一化以确保与框 2.1 的求和法则一致. 与较低期望自由能相关的策略被赋予较高概率，并成为生物体预期执行的策略.

最终，推断出我们正在执行某个特定策略会影响我们预测的感觉数据. 例如，包含弯曲肘部的策略意味着对来自二头肌和三头肌的本体感觉输入作出预测. 这建立了规划与行动之间的联系：与计划相关的预测转化为行动，从而消除与测得的本体感觉数据之间的差异（见第 2.3 节）.

2.8 什么是期望自由能？

迄今为止，我们假设生物体在规划过程中根据期望自由能对其策略评分，但尚未说明期望自由能究竟是什么. 与变分自由能一样，期望自由能可按若干数学上等价的方式分解；每一种方式都提供了看待这一量的不同视角：

$$
\begin{aligned}
G(\pi) &= -\underbrace{\mathbb{E}_{Q(\tilde{x},\tilde{y}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{x} \mid \tilde{y},\pi) \| Q(\tilde{x} \mid \pi)]]}_{\text{信息增益}} - \underbrace{\mathbb{E}_{Q(\tilde{y}|\pi)}[\ln P(\tilde{y} \mid C)]}_{\text{实用价值}} \\
&= \underbrace{\mathbb{E}_{Q(\tilde{x}|\pi)}[H[P(\tilde{y} \mid \tilde{x})]]}_{\text{期望模糊度}} + \underbrace{D_{\mathrm{KL}}[Q(\tilde{y} \mid \pi) \| P(\tilde{y} \mid C)]}_{\text{风险（结果）}} \\
&\leq \underbrace{\mathbb{E}_{Q(\tilde{x}|\pi)}[H[P(\tilde{y} \mid \tilde{x})]]}_{\text{期望模糊度}} + \underbrace{D_{\mathrm{KL}}[Q(\tilde{x} \mid \pi) \| P(\tilde{x} \mid C)]}_{\text{风险（状态）}} \\
&= -\underbrace{\mathbb{E}_{Q(\tilde{x},\tilde{y}|\pi)}[\ln P(\tilde{y},\tilde{x} \mid C)]}_{\text{期望能量}} - \underbrace{H[Q(\tilde{x} \mid \pi)]}_{\text{熵}}, \qquad (2.6) \\
Q(\tilde{x},\tilde{y} \mid \pi) &\triangleq Q(\tilde{x} \mid \pi) P(\tilde{y} \mid \tilde{x}).
\end{aligned}
$$

第一种分解或许在直觉上最有用，因为它以完全相同的单位（奈特）表达寻求新信息的价值，即探索，和寻求偏好观测的价值，即利用，从而消解了行为心理学中经典的利用—探索困境. 通过最小化期望自由能，这些项之间的相对平衡决定了行为主要是探索性的还是利用性的. 注意，实用价值表现为关于观测的先验信念，其中参数 C 包含偏好. 先验信念与偏好之间可能不够直观的联系将在第 7 章阐明；目前我们指出，在假设有价值的结果是表征每个智能体的那类结果（例如体温为 37 摄氏度）的条件下，这一项可以视为期望效用或价值.

信息增益项源自第 2.5 节讨论的散度，正是该散度确保自由能是惊异的上界. 不过，此处有一个转变：我们希望选择使期望散度最大化的策略，而不是最小化散度，因此得到信息增益. 这种转变是由于我们现在对尚未观测到的结果上的对数概率取平均. 这一微妙之处可以从结果所扮演角色的变化来理解：评价结果的自由能时，结果是后果；评价期望自由能时，结果则扮演原因的角色，因为它们是隐藏在未来、却能解释当前决策的变量.

由此得到的信息增益会惩罚存在从观测到状态的多对一映射的观测；这里的含义

是，在不同状态下可以获得相同的观测，这使精确信念更新无法实现. 在人工智能和机器人学中，产生相同观测的状态，例如迷宫中看起来完全相同的两个丁字路口，有时称为混叠状态，通常难以用没有推断或记忆的简单刺激—反应方法处理. 问题在于，单凭当前观测无法知道自己处于哪个状态. 由于这类情形的信息增益潜力很低，主动推断会首先避免进入这类情形.

一个简单的例子有助于阐明信息增益或认知价值与实用价值的区别，并说明为什么在大多数现实情形中需要同时追求实用价值与认知价值. 设想一个人想喝浓缩咖啡，他知道镇上有两家不错的咖啡馆：一家只在周一至周五营业，另一家只在周末营业. 如果他不知道今天是星期几，就必须先选择一个有认知价值、能够消除不确定性的行动，即查看日历的认知行动；然后才能选择一个具有实用价值并带来奖励的行动，即前往正确咖啡馆的实用行动. 这个例子说明，在大多数不确定情形中，必须先采取认知行动消解不确定性，才能有把握地选择实用行动. 不考虑选项所提供的认知机会的策略选择方法只能通过随机数生成器选择策略，因而往往喝不到浓缩咖啡. 因此，仅考虑实用价值的方案一般局限于没有认知不确定性的情况，例如一个人已经知道星期几，因而可以直接前往正确的咖啡馆.

式 (2.6) 的第二种分解采用风险和期望模糊度. 这两个量分别类似于复杂度和不准确度：风险是期望复杂度，模糊度是期望不准确度. 风险是经济学中的常用概念，它对应于策略和后果之间可能存在一对多映射，即同一策略下可能偶然得到多个不同结果. 一个例子是具有随机奖励的赌博场景，例如单臂老虎机；在此场景中，人们可能知道奖励分布，例如有 10% 的概率获得奖励. 经济学将其称为风险情形，因为同一动作（拉动手柄）之后可能得到两种不同观测：获得奖励或没有奖励. 这意味着必须选择能够容纳不确定性的策略或计划. 在主动推断这样的风险敏感方案中，问题是选择概率结果在 KL 散度意义下符合先验偏好的策略. 简言之，当复杂度代价和风险都度量对先验信念的偏离时，最小化复杂度代价就成为最小化风险.

类似地，模糊度对应于状态与结果之间的模糊映射所造成的期望不准确度. 即使完全确定产生结果的状态，如果预期结果的分布仍高度分散或具有高熵，这一映射就是模糊的. 例如，以晴天还是下雨为条件的抛硬币正反面概率具有最大模糊度，因为天气与各占一半的正反面概率之间没有关系. 因此，不可能通过观察到反面而获得关于天气的信息. 注意，大多数情形同时具有风险和模糊度，这意味着状态与结果之间以及策略与结果之间都存在多对一映射. 请记住，结果或观测是唯一能够观测到的变量. 主动推断会自动处理这些情形，因为期望自由能同时包含风险项和模糊度项.

式 (2.6) 第三行将风险重新表述为关于状态的信念与以状态定义的偏好之间的散度，从而突出期望自由能的另一种表述. 这种形式的一个吸引人之处是，它可以重排为期望能量与熵，类似于变分自由能（式 (2.5)）. 尽管这一关系很有吸引力，其缺点在于它假定状态空间先验已知，从而能够将先验偏好与状态相关联. 在大多数情况下，这不是问题，选择用状态还是结果定义偏好在实践中意义不大. 但通常的做法是按结果指定偏好，从而既能学习状态空间本身，又能保持外在动机.

总之，期望自由能可以按风险与模糊度分解，也可以按实用价值与认知价值分解. 这些分解有助于形式化地理解主动推断所处理的各种情形，也有助于认识主动推断如何涵盖若干决策方案：这些方案可以通过忽略期望自由能的一个或多个分量得到（图 2.6）. 如果去掉先验偏好，实用价值就变得无关，所有行动都由认知机会驱动；因此这类方

案只能处理不确定性的消解. 去掉先验偏好后，负期望自由能在注意探索的语境中称为期望贝叶斯惊异，在自主学习的语境中称为内在动机. 如果去掉模糊度，所得方案对应控制理论中的风险敏感控制或 KL 控制. 最后，如果同时去掉模糊度和先验偏好，唯一剩下的命令便是最大化观测的熵；若采用式 (2.6) 第三行的表述，则是最大化状态的熵. 这可以理解为不确定性采样或保持选择余地. 主动推断揭示了这些方案之间的形式关系及其适用的有限情形.

期望自由能（Expected free energy）

$$G(\pi) = -\mathbb{E}_{Q(\tilde{y}|\pi)}\underbrace{[\ln P(\tilde{y} \mid C)]}_{1} - D_{\mathrm{KL}}\left[\underbrace{Q(\tilde{y} \mid \tilde{x})}_{2}\underbrace{Q(\tilde{x} \mid \pi)}_{3} \middle\| \underbrace{Q(\tilde{y} \mid \pi)}_{4}\underbrace{Q(\tilde{x} \mid \pi)}_{5}\right].$$

项 2、3、4、5

$$D_{\mathrm{KL}}[Q(\tilde{y} \mid \tilde{x})Q(\tilde{x} \mid \pi) \| Q(\tilde{y} \mid \pi)Q(\tilde{x} \mid \pi)] = \mathbb{E}_{Q(\tilde{y}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{x} \mid \tilde{y}, \pi) \| Q(\tilde{x} \mid \pi)]].$$

贝叶斯惊异（Bayesian surprise）、最优贝叶斯设计（Optimal Bayesian design）、内在动机（Intrinsic motivation）、信息最大化原理（Infomax principle）

项 1、3、4、5

$$D_{\mathrm{KL}}[Q(\tilde{y} \mid \pi) \| P(\tilde{y} \mid C)].$$

风险敏感策略（Risk-sensitive policies）、KL 控制（KL control）

仅项 1

$$\mathbb{E}_{Q(\tilde{y}|\pi)}[\ln P(\tilde{y} \mid C)].$$

贝叶斯决策理论（Bayesian decision theory）、期望效用理论（Expected utility theory）

图 2.6: 通过从自由能方程中去掉各项可以得到的各种方案. 上面板给出期望自由能的组成项；下面板分别展示去掉先验偏好 (1)、模糊度 (2), 或除先验偏好以外所有项后得到的方案. 这些量在不同领域有多种名称，但都可视为同一个期望自由能的组成部分. 图中 Bayesian surprise、Optimal Bayesian design、Intrinsic motivation、Infomax principle 分别为贝叶斯惊异、最优贝叶斯设计、内在动机和信息最大化原理；Risk-sensitive policies、KL control、Bayesian decision theory、Expected utility theory 分别为风险敏感策略、KL 控制、贝叶斯决策理论和期望效用理论.

虽然我们仔细分解了期望自由能，以便不同读者理解这个泛函，但如何划分它并无对错之分. 我们将在本书后半部分看到，为什么某类自主系统凭借其存在就必须选择看起来像是在最小化期望自由能的行动. 从这一视角看，认知（探索）与实用（利用）的命令，或风险与模糊度之间，都不存在优先地位. 这些可能是虚假的二分，不过是同一

生存问题的一体两面.

2.9 低路径的终点

介绍了变分自由能和期望自由能这两个不同的概念后，我们现在可以考虑它们共同实现什么. 这标志着通向主动推断的低路径到达终点：它从无意识推断的观念出发，经过贝叶斯脑、知觉与行动的二重性，最后到达作为推断的规划.

变分自由能是主动推断的核心. 它度量内部生成模型与当前及过去观测之间的拟合程度. 生物通过最小化变分自由能来最大化模型证据. 这确保生成模型成为环境的良好模型，并使环境符合模型.

期望自由能是为规划中的备选策略评分的方式. 它从根本上是前瞻性的，因为它考虑可能的未来观测；也是反事实性的，因为可能的未来观测以可执行的策略为条件. 期望自由能衡量行动策略相对于偏好的未来状态和观测的合理性. 通过以负期望自由能为策略评分，进行主动推断的生物实际上相信自己会执行使这一量最低的行动过程. 用心理学语言说，这意味着生物对策略的信念直接对应于它的意图，而它通过行动实现这一意图.

从概念上看，我们可以将变分自由能最小化和期望自由能最小化分别与两个相互嵌套的推断回路联系起来. 变分自由能最小化是主动推断的关键外回路，足以优化知觉和关于策略的信念. 主动推断智能体也可以具有一个关于其行动后果的生成模型，因而能够评估期望自由能，即内回路. 这种对未来进行规划的能力为策略提供概率值，从而支持前瞻性的行动选择（Friston, Samothrakis, and Montague 2012; Pezzulo 2012）.

2.10 小结

主动推断是关于有生命的人造物如何通过知觉和行动最小化惊异或惊异的可处理替代量——变分自由能——以维系自身存在的理论. 本章试图从将知觉作为推断的贝叶斯处理出发，推动这一思想，并将其扩展到行动领域. 贝叶斯推断依赖关于感觉观测如何产生的生成模型，该模型以概率方式编码生物体关于世界的隐含知识，并将其形式化为先验信念以及不同状态和策略下的期望结果.

主动推断的独特处理迫使我们重新审视贝叶斯推断中先验的通常含义. 预期状态是偏好的状态，包括生物体的生存条件，例如特定生态位的目标状态；与之相反，令人惊异的状态是不被偏好的. 这样一来，主动推断智能体通过实现其预期来确保自身生存. 鉴于先验概念与支撑生物体存在的条件之间的重要联系，我们也可以说，在主动推断中，智能体的身份与其先验同构. 随着本书展开，这些术语将变得更加熟悉.

注意，在这一观点中，惊异或信息惊异是信息论中的形式构造，不一定等同于日常心理学中的概念. 粗略而言，生物体的状态偏离编码偏好状态的先验越多，其惊异程度就越大. 因此，主动推断归结为这样的思想：生物体或其大脑必须主动最小化惊异以维持生命. 在某些条件下，惊异最小化可理解为减少模型与世界之间的差异. 更一般地，主动推断实际最小化的量是变分自由能. 变分自由能是惊异的上界近似，可以利用化学或神经元消息传递以及生物体生成模型可获得的信息来高效最小化.

关键的是，知觉和行动都以互补方式最小化变分自由能：前者改善其后验信念估计，

后者执行行动，有选择地采样预期的内容. 此外，主动推断还通过遵循与最小模糊度和风险相关的策略来最小化期望自由能. 期望自由能由此将主动推断扩展到前瞻性和反事实形式的推断. 至此，我们完成了沿低路径通向主动推断的旅程. 第 3 章将沿高路径行进，从第一性原理和自组织出发得出同样的结论.

Chapter 3

通向主动推断的高路径

> 能够模拟未来的生存机器比只能通过外显试错学习的生存机器领先一步. 外显尝试的问题在于它耗费时间和能量；外显错误的问题在于它往往是致命的. 模拟既更安全，也更迅速.
>
> —Richard Dawkins

3.1 引言

第 2 章从进行近似贝叶斯推断的方法出发，说明了引入自由能的动机，即通向主动推断的低路径. 本章从另一种视角，即高路径，来引入自由能. 高路径将这一推理倒转：从统计物理的第一性原理和生物体必须维持自身存在、即避免惊异状态这一核心命令出发，再将自由能最小化引作该问题在计算上可处理的解法. 本章揭示近似贝叶斯推断中变分自由能最小化与模型证据最大化或自我证成之间的形式等价性，从而揭示关于适应性系统的自由能视角和贝叶斯视角之间的联系. 最后，本章讨论主动推断如何提供一种理解（最优）行为的、从第一性原理出发的新视角.

主动推断是一种关于生物体如何通过知觉和行动，最小化惊异或其可处理的替代量——变分自由能——以维持自身存在的理论. 它从第一性原理出发，提出了一种基于信念的理解行为和认知的新方案，这一方案具有众多经验含义.

通向主动推断的高路径从以下前提出发：为了生存，任何生物体都必须将自身维持在一组合适的偏好状态中，同时避免环境中其他不被偏好的状态. 这些偏好状态首先由特定生态位的进化适应所定义；不过，正如后文所示，在较高级的生物体中，它们还可以扩展到习得的认知目标. 例如，为了生存，鱼必须待在一个舒适区域内，即宇宙所有可能状态的一个很小子集：它必须待在水中. 类似地，人必须确保其内部状态，例如体温和心率等生理变量，始终处于可接受的范围；否则人就会死亡，或者更准确地说，变成别的东西，例如一具尸体. 这个可接受范围或舒适区域通过约定定义了某物要成为该物所必须处于的特征状态.

生物体通过在多个层面上对自身状态，例如体温，施加主动控制来解决这一基本生物学问题. 这些层面从出汗等自动调节机制（生理学），到购买和饮用饮料等认知机制（心理学），再到分配空调系统等文化实践（社会科学）.

从更形式化的视角看，主动推断将生存这一生物学问题或对生存的解释表述为惊异最小化. 这一表述依赖于信息论中对惊异状态的技术定义：惊异状态本质上标示出生物体舒适区域之外的状态. 在此基础上，主动推断提出自由能最小化是一种可行且具有生物学基础的方式，使生物体或适应性系统能够最小化感觉遭遇的惊异.

3.2 马尔可夫毯

任何适应性系统的一个重要前提是，它必须与环境保持一定的分离和自主性；否则它只会消散、溶解，进而屈从于环境动力学. 若没有这种分离，就不会有需要最小化的惊异：必须有某种东西感到惊异，也必须有某种东西使之惊异. 换言之，至少存在系统和环境两个事物，而且二者可以相互区分. 以形式方式表达系统与其余环境之间分离的一种方法，是使用马尔可夫毯这一统计构造（Pearl 1988），见框 3.1.

框 3.1：马尔可夫毯

马尔可夫毯是本书反复出现的一个重要概念（Friston 2019a, Kirchhoff et al. 2018, Palacios et al. 2020）. 从技术上说，毯 b 定义如下：

$$\mu \perp x \mid b \quad \Longleftrightarrow \quad p(\mu, x \mid b) = p(\mu \mid b)p(x \mid b).$$

这以两种不同但等价的方式说明：如果已知 b，变量 μ 与变量 x 条件独立. 换言之，如果知道 b，那么知道 x 不会提供关于 μ 的额外信息. 一个常见例子是马尔可夫链：过去导致现在，现在导致未来. 在这种情况下，过去只能通过现在影响未来. 这意味着，在已知现在的前提下，了解过去不会获得关于未来的额外信息.

如果已知系统中的条件依赖关系，可以遵循一个简单规则来识别马尔可夫毯. 给定变量的毯包含其父节点（它所依赖的变量）、子节点（依赖它的变量），以及在某些情况下，其子节点的其他父节点.

简言之，马尔可夫毯是介导系统与环境之间所有统计相互作用的变量集合. 图 3.1 展示了对动态情形下马尔可夫毯的一种解释. 此处条件独立关系还补充了动力学约束，使得流不依赖于毯另一侧的状态.

图 3.1 中的马尔可夫毯区分了适应性系统的内部状态，即大脑活动，与环境的外部状态. 此外，图中还标出感觉状态和主动状态两个状态，它们构成在统计上分隔内部与外部状态的毯. 统计分离意味着，如果已知主动状态和感觉状态，外部状态将不再提供有关内部状态的额外信息，反之亦然. 在动力学背景下，这通常被解释为：内部状态不能直接改变外部状态，但能通过改变主动状态间接地改变外部状态；类似地，外部状态不能直接改变内部状态，但能通过改变感觉状态间接地改变内部状态.

这是对经典行动—知觉循环的重述：适应性系统与环境分别只能通过行动和观测相互作用. 这一重述有两个主要好处. 首先，它形式化地表达了适应性系统的内部状态独立于环境动力学，因而能够抵抗其影响. 其次，它为适应性系统最小化惊异的方式提供了框架，突出了它们可以获得的内部、感觉和主动状态. 具体而言，惊异相对于感觉状态定义，而内部和主动状态的动力学则是最小化感觉状态惊异的手段.

此处需要注意的关键点是，适应性系统的内部状态与外部状态存在形式关系. 这是因为马尔可夫毯两侧具有某种对称性：两者都影响毯状态，也受毯状态影响. 由此，我们可以构造以毯状态为条件的内部和外部状态的条件概率分布. 由于这些分布以相同的毯状态为条件，我们可以将成对的内部和外部期望状态联系起来. 换言之，平均而言，内部和外部状态会获得某种广义同步性；这正如将两个摆分别连接在一根木梁两端时所预期的那样. 随着时间推移，两个摆逐渐同步，每个摆都通过木梁的间接影响而变得可以预测另一个摆（Huygens 1673）. 图 3.2 直观地展示了这种关系. 这意味着，如果能

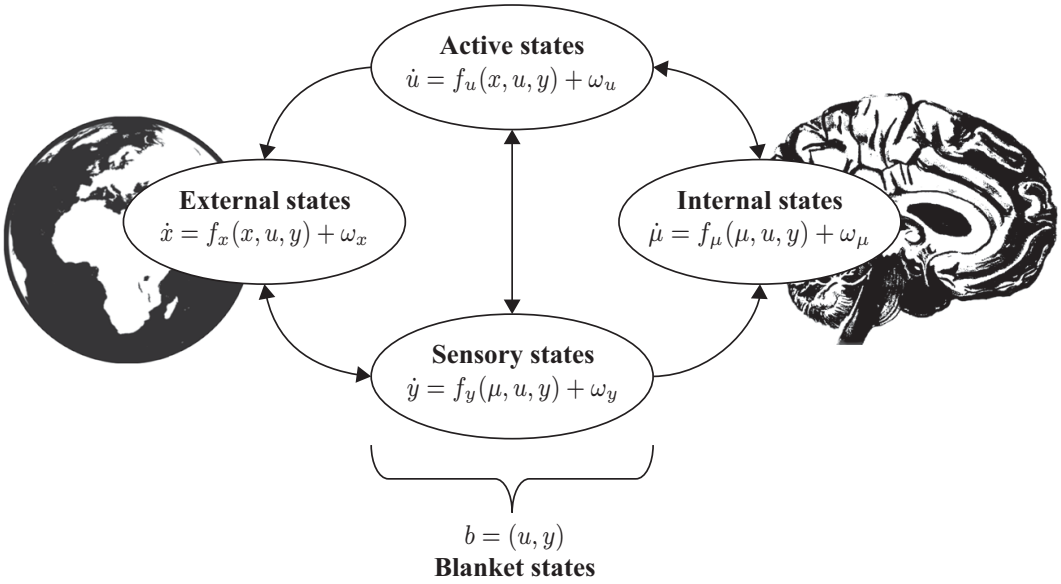


图 3.1: 动态马尔可夫毯将适应性系统（此处为大脑）与环境分开. 每组状态的动力学由确定性流和额外的随机涨落 ω 决定；确定性流由给出平均变化率的函数 f 指定. 箭头表示每个变量对其他变量变化率的影响方向，从技术上说即相应雅可比矩阵的非零元素. 这只是一个例子：可以用马尔可夫毯将整个生物体与环境分开，或将多个马尔可夫毯相互嵌套. 例如，大脑、生物体、二元群体和社区可用相互嵌套的不同马尔可夫毯来构想（形式处理见 Friston 2019a；Parr, Da Costa, and Friston 2020）. 不同领域使用不同变量记号，容易造成混淆：感觉状态有时记为 s，外部状态记为 η，主动状态记为 a. 本书在此选择与其他章节一致的变量. 图中 Active、External、Internal、Sensory 和 Blanket states 分别表示主动、外部、内部、感觉和毯状态.

够写出以马尔可夫毯为条件的外部和内部状态的独立分布，那么这两个状态就会经由毯相互提供信息.

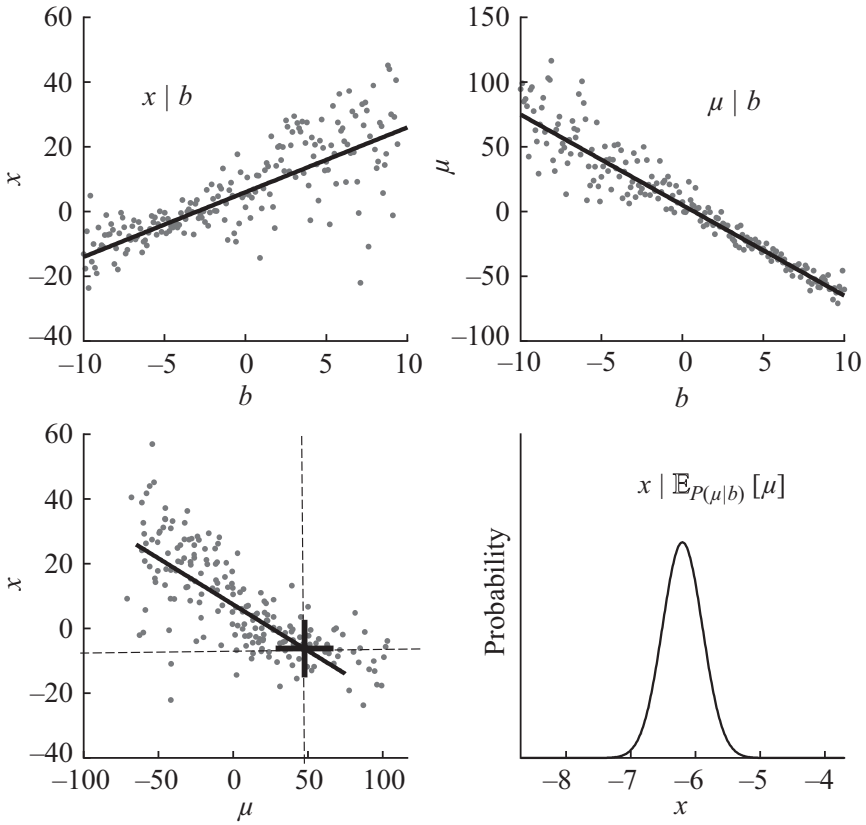


图 3.2: 马尔可夫毯的平均内部状态与外部状态分布之间的关联. 上：假设条件概率采用线性高斯形式，分别显示给定毯状态时外部和内部状态条件分布的样本；粗黑线表示给定相应毯状态时这些变量的平均值. 左下：以相同数据说明共享马尔可夫毯所产生的内部和外部状态同步，此处为反向同步. 虚线和黑色十字表明，如果知道平均内部状态（竖线），就可以确定平均外部状态（横线）及其周围的分散程度. 右下：可以将平均内部状态与外部状态上的分布联系起来. Probability 表示概率.

这种同步性使内部状态呈现出表征或建模外部状态的样子，从而与第 2 章引入的惊异最小化思想联系起来. 这是因为惊异依赖于关于感觉数据如何产生的内部模型. 回顾一下，最小化感觉观测的惊异，即负对数概率，等同于最大化模型证据或边缘似然；后者正是该模型下感觉观测的概率. 这一惊异最小化观念可以从两个等价视角，即贝叶斯视角和自由能视角来理解，下面将讨论它们.

3.3 惊异最小化与自我证成

从贝叶斯视角看，具有马尔可夫毯的智能体似乎在对外部环境建模：内部状态平均而言对应于系统外部状态的一种概率表征，即近似后验信念（图 3.2）. 内部状态的动力学对应于对外部状态进行某种形式的近似贝叶斯推断，因为内部状态的运动改变了相关

的概率分布；这一分布由一个关于感觉如何产生的隐含生成模型提供，其中感觉在马尔可夫毯的术语中称为感觉状态. 如果重新将智能体视为由内部状态和毯状态构成，就可以讨论智能体的生成模型.

关键的是，智能体的生成模型不能仅仅模仿外部动力学，否则智能体只会跟随外部的耗散动力学. 相反，模型还必须指定智能体存在所偏好的条件，或者智能体为维持自身存在、以占据特征状态的方式满足其存在标准而必须到达的状态区域. 这些偏好状态或观测可以指定为模型的先验. 这意味着模型隐含地假定：如果满足存在标准，其偏好的先验感觉更可能发生，即惊异程度更低. 这意味着它具有隐含的乐观偏差. 这种乐观偏差是必要的，使智能体能够超越对外部动力学的简单复制，规定支撑其偏好状态或特征状态的主动状态.

按照这一表述，可以把相对于先验偏好的最优行为视为通过知觉和行动最大化模型证据. 模型证据概括了生成模型拟合或解释感觉的程度. 良好的拟合表明模型成功地说明了其感觉，这是推断的描述性一面；与此同时，由于偏好的感觉惊异程度较低，模型也实现了其偏好的感觉，这是推断的规定性一面. 这样的良好拟合保证了惊异最小化，因为最大化模型证据 $P(y)$ 在数学上等价于最小化惊异 $\mathfrak{I}(y) = -\ln P(y)$.

更简洁地重述上述论证的一种方法，是说任何适应性系统都在进行“自我证成”（Hohwy 2016）. 这里的自我证成意味着采取行动获取与内部模型一致，即为内部模型提供证据的感觉数据，从而最大化模型证据.

3.3.1 惊异最小化作为哈密顿最小作用量原理

在前几节中，我们断言必须最小化惊异，但没有详细说明原因. 尽管自我证成的底层物理学细节超出了本书范围（详见 Friston 2019b），这里仍简要概述其原理. 这些原理的基础是：具有马尔可夫毯的生物体随时间维持存在，抵抗环境涨落的弥散作用. 马尔可夫毯的持续存在意味着毯状态的分布随时间保持不变. 简单地说，这意味着感觉或主动状态一旦偏离该分布下高概率的区域，就必须由状态的平均流加以纠正；平均流正是图 3.1 中流的确定性部分. 用物理学家的表述来说，处于稳态的随机系统具有这样一种动力学：它们平均而言沿能量函数或哈密顿量下降，而该函数可以解释为负对数证据或惊异. 这类似于小球从山顶的高重力势能处滚向盆地中的低能量处，见图 3.3.

对于图 3.3 左侧的系统，每次涨落导致系统移动到较低概率的状态，这一偏离都会由沿概率梯度向上的运动加以纠正，使系统在概率密集区域中停留的时间比例更大. 关键见解是，该系统通过平均意义上的惊异最小化，将感觉状态维持在狭窄范围内；相比之下，右侧系统的惊异无限增长.

惊异最小化使生物体能够暂时抵抗热力学第二定律；第二定律指出，熵或系统状态的分散程度总是增长. 这是因为，平均而言，熵是惊异的长期平均；平均而言，最大化观测的对数概率等价于最小化香农熵[2]：

$$H[P(y)] = \mathbb{E}_{P(y)}[\mathfrak{I}(y)] = -\mathbb{E}_{P(y)}[\ln P(y)]. \tag{3.1}$$

确保系统以高概率占据一小部分感觉状态，等价于维持一个特定的熵. 这是自组织系统的一个定义性特征，控制论早已认识到这一点.

从生理学视角看，惊异最小化将稳态调节的思想形式化. 当某个感受器的值离开其最优范围时，负反馈机制开始发挥作用，使这些偏离反向. 从控制论视角，我们可以相

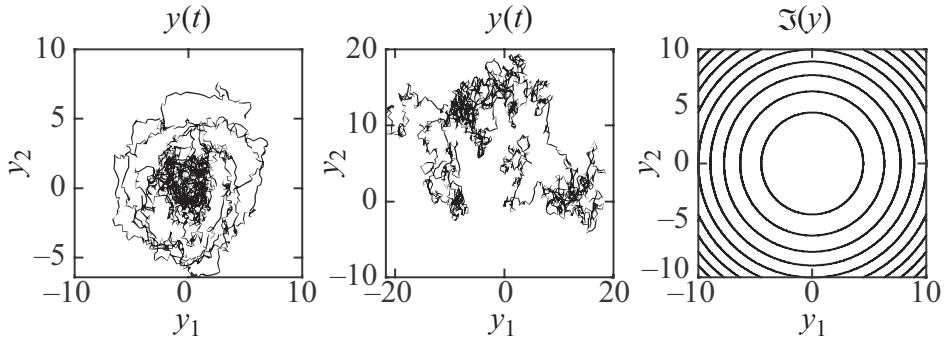


图 3.3: 左：具有非平衡[1]稳态的二维随机动力系统所经过的路径；它可以被解释为最小化自身的惊异，惊异在右侧等高线图中给出. 右：中心是惊异程度最低的区域，远离中心的圆周代表惊异程度逐渐增大的区域. 中：作为对比，系统从同一位置 $(5, 5)$ 出发，具有相同幅度的随机涨落，但其动力学与惊异无关. 它不仅进入空间中更令人惊异的区域，而且无法达到任何形式的稳态，随时间不受约束地弥散. 主动推断的适用范围限于类似左图的系统：它们以平均流抵消随机涨落，从而随时间保持自身形态.

对于某个期望的稳态概率密度来理解最优行为. 换言之，如果定义了一个偏好结果的分布，最优行为将涉及系统向该分布演化并维持这一分布.

如第 2 章所见，自由能是惊异的上界，这提示在随机涨落下可以通过最小化自由能获得最优行为. 回顾一下，自由能与惊异之差是精确后验概率，即给定毯状态时外部状态的分布，与近似后验概率，即给定平均内部状态时外部状态的分布之间的散度. 因此，可以把内部状态的运动视为最小化该散度，这又使主动状态能够平均而言最小化伴随感觉状态的惊异. 换言之，由自由能最小化产生的最优行为是惊异程度最低的行为，它从当前状态到期望状态遵循最小作用量[3]路径，即将哈密顿最小作用量原理应用于行为.

图 3.3 展示了具有随机吸引子的一个非常简单的系统. 它类似于恒温器：用控制论术语说，它只有一个设定点，不能学习或规划. 主动推断旨在使用相同的解释框架涵盖复杂得多、适应性更强的系统. 在这里，最简单系统与更复杂系统之间的差别可以归结为吸引子形状的不同，从不动点到越来越复杂的、游走性的动力学. 从这一视角看，可以将生物体理解为持续寻求过度稳定与过度弥散之间的折中；主动推断旨在解释如何实现这种折中.

3.4 推断、认知与随机动力学之间的关系

物理学家 E. T. Jaynes 曾著名地指出，推断、信息论和统计物理是看待同一事物的不同视角（Jaynes 1957）. 在前几节中，我们讨论了贝叶斯视角与统计物理视角如何提供两种等价的方式来理解惊异最小化和最优行为，这实际上为 Jaynes 的三元组增加了一种认知形式. 这些学派之间的等价关系很有吸引力，但对于不熟悉各自形式体系的读者而言可能令人困惑，因为同一量会用许多不同词语来称呼. 为帮助澄清，本节阐述贝叶斯与统计物理视角之间的主要等价关系及其认知解释；概要见表 3.1 和框 3.2.

表 3.1: 统计物理、贝叶斯推断和信息论及其认知解释

统计物理	贝叶斯推断与信息论	认知解释
最小化变分自由能	最大化模型证据或边缘似然；最小化信息惊异或自信息	知觉与行动
最小化期望自由能；哈密顿最小作用量原理	推断最可能或惊异程度较低的行动过程	作为推断的规划
达到非平衡稳态	进行近似贝叶斯推断	自我证成
能量函数上的梯度流；自由能梯度下降	模型证据梯度上升；信息惊异梯度下降	神经元动力学

框 3.2：统计物理与主动推断中的自由能

自由能概念在统计物理中广泛用于刻画例如热力学系统. 尽管主动推断使用完全相同的方程，它们在这里被用于刻画智能体相对于生成模型的信念状态. 因此，当我们说主动推断智能体最小化其变分自由能时，指的是改变其信念状态的过程，而不是例如构成其身体的粒子. 为避免误解，我们使用变分自由能一词，采用机器学习中更常见的术语. 另一个更微妙的要点是，自由能概念常用于平衡态统计热力学. 主动推断的对象是生物体，或处于非平衡稳态的开放系统；这些系统与环境持续进行相互交换. 这是一个令人振奋的新领域（Friston 2019a）.

3.4.1 变分自由能、模型证据与惊异

第一个重要的等价关系是贝叶斯推断中最大化模型证据或边缘似然与最小化变分自由能之间的关系；二者都使惊异最小化. 考虑对难处理的推断问题的一种特定近似解法，即变分推断时，这种等价性便显现出来. 变分推断通过最小化自由能，将推断问题重述为优化问题. 自由能的最小值对应于对精确解的近似最佳的点. 用形式化方式表达这一点，有助于阐明三个量之间的关系：

$$\underbrace{\mathfrak{I}(y \mid m)}_{\text{惊异}} = -\ln \underbrace{P(y \mid m)}_{\text{模型证据}} \leq \underbrace{D_{\mathrm{KL}}[Q(x) \| P(x \mid y, m)] - \ln P(y \mid m)}_{\text{变分自由能}}. \tag{3.2}$$

与第 2 章不同，在式 (3.2) 中，我们明确地将所有量以模型 m 为条件，以强调这些量依赖于我们关于 y 如何生成的模型；使用不同模型时，它们也会改变. 这些量之间的等价关系引出一个问题：为什么有必要区分它们？主要原因是，与模型证据不同，变分自由能可以高效地最小化.

回顾第 2 章，只有当 KL 散度项变为零时，变分自由能才与负模型证据或惊异严格等价. 这并非总能做到，但可以使该项接近零. 因此，在不断为 $Q(x)$ 寻找更好取值的过程中，变分自由能也更接近惊异. 我们已经多次强调这一点，因为自由能与惊异之间的核心关系是本书的基础. 具体而言，自由能是惊异的上界，可以等于或大于惊异；超出的部分由 KL 散度量化.

一个有趣的方面是，任何最小化惊异的系统，包括图 3.2 中的非常简单的系统，也都在最小化自由能，此时 $Q(x)$ 始终设为等于精确后验概率，即将 KL 散度设为零. 关于认知系统与非认知系统的区别，一种观点认为，后者的 KL 散度始终为零，而认知系统

必须通过最小化这一项的知觉过程，才能保证其行动最小化惊异. 注意，最小化散度是知觉唯一能够做到的事. 这使内部状态的运动非常重要：它们所参数化的分布（图 3.2）应尽可能接近精确后验. 然而，知觉无法最小化变分自由能的第二个组成部分，即对应实际惊异的证据项，因为它不能改变已经获得的感觉. 智能体只有通过改变感觉的行动，才能最小化变分自由能的第二个组成部分，消除惊异，或者等价地说，最大化模型证据. 这强调了给定内部状态时主动状态的运动在自我证成中的作用.

一个例子有助于说明这一点. 假设你的生成模型预测给定饥饿程度时血糖水平的分布，其中相对较高和较低的血糖水平分别对应饱腹和饥饿. 进一步假设，这个模型为饱腹以及相应的较高血糖水平赋予更高的先验概率，使低血糖成为令人惊异的情况. 假设你起初不确定自己有多饥饿，并感知到低血糖. 知觉使你推断自己饿了并体验到饥饿，从而消除 KL 散度. 但知觉不能进一步减少你的惊异，也不能减少先验预期的高血糖与感知到的低血糖之间的差异，因为它不能作用于你的感觉或其生理成因. 只有采取行动改变所获得感觉的隐含来源，例如吃一份甜点，才能最小化惊异.

总之，知觉可以通过减少近似后验与真实后验之间的差异来最小化变分自由能，但无法进一步最小化惊异. 惊异最小化的下一步需要通过行动改变所获得的感觉；推断也由此超越知觉，变得主动.

3.4.2 期望自由能与最可能轨迹的推断

另一个重要的等价关系是最小化期望自由能与推断最可能的行动过程或策略之间的关系. 这超出了指定状态空间中惊异程度最低的部分，转而讨论通向该部分或位置的不同路径各有多令人惊异. 这些备选路径以策略表达，而策略本质上是跨越各状态的轨迹. 值得注意的是，在主动推断中，如果执行某一策略，该策略的对数概率被设定为与期望自由能成比例. 这意味着最可能或惊异程度最低的路径被设定为最小化期望自由能的路径. 这一表述等价于物理学中作用量的定义：它通过能量的积分或求和对路径的概率评分. 尽管物理系统可能涉及一个假设轨迹空间，它实际遵循的是作用量最小的路径，即哈密顿最小作用量原理. 下一节将阐明主动推断与哈密顿最小作用量原理之间的类比.

3.5 主动推断：理解行为与认知的新基础

在最优控制、强化学习和经济学等领域，按照贝尔曼方程，行为优化来自状态的价值函数（Sutton and Barto 1998）. 其基本思想是，每个状态或状态—行动对都被赋予一个价值，代表该状态对智能体而言有多好. 状态或状态—行动对的价值通常通过试错学习：统计从这些状态出发后获得奖励的次数，以及获得奖励所需的时间. 行为通过到达高价值状态来优化奖励的获取，从而利用学习历史.

相比之下，在主动推断中，行为是推断的结果，其优化是信念的函数. 这一表述统一了先验信念和偏好两个概念. 如上所述，使用期望自由能概念相当于赋予智能体一种隐含的先验信念，即它将实现自己的偏好. 因而，智能体对某一行动过程的偏好，就成为关于它预期未来会做什么、遇到什么的信念，或关于它将访问的未来状态轨迹的信念. 这用先验信念的概念取代了价值的概念. 对具有强化学习背景（其中价值和信念是分开

的）或贝叶斯统计背景（其中信念不蕴含任何价值）的人来说，这一做法显然有些奇怪. 然而，它很有力量，至少有三个原因.

首先，它自动蕴含一个自洽的目的性或目的论行为过程模型，与控制论表述相似. 如果赋予主动推断智能体某种先验偏好，它就会行动以实现这些偏好，因为这是唯一与其先验信念一致的行动过程：它相信自己会行动以满足预期. 注意，所得的偏好行动过程或策略在实验中可直接测量，而价值函数或先验信念需要通过推断获得，因此即使不是同义反复，也是一种更间接的度量.

其次，将行为表示为信念（概率分布）的泛函，自然蕴含信念程度和不确定性等概念. 这些概念支撑适应性行动的重要方面，但在贝尔曼表述中不能直接获得. 同样，这一表述为序列动力学和游走行为的建模提供了更大灵活性；这些行为较难用状态价值函数建模（Friston, Daunizeau, and Kiebel 2009）.

第三，在这种表述下，最优行为遵循统计物理中的哈密顿最小作用量原理. 主动推断在行为是信念函数这一思想上更进一步：它还假设行为成为一个能量函数，而主动推断智能体最可能的行动过程就是最小化自由能的过程. 一个深刻的后果是，生物体按照哈密顿最小作用量原理行动：它们沿最小阻力路径前进，直至达到稳态或一个状态轨迹，图 3.3 所示的随机动力系统行为便是例证. 这是一项基本假设，使主动推断区别于基于贝尔曼表述的其他行为与认知理论.

下面简要说明我们在哈密顿物理与主动推断之间作类比的含义；这一类比有三个层次. 第一，主动推断对行为科学与生命科学所提供的进展，可以与拉格朗日[4]和哈密顿表述对牛顿力学描述所提供的进展相比. 牛顿力学最初用微分方程表述，包括牛顿著名的第三定律，它表达加速度与力之间的正比关系.[2] 考虑动力系统的守恒量则提供了一个互补的力学视角，随后可以从这些守恒定律推导牛顿动力学. 它们为进一步理论发展提供基础，并构成随机、相对论和量子物理部分内容的基础. 类似地，主动推断通过指定可以导出动力学的量——自由能——重新表述原本可能由一系列微分方程建立的神经元和行为动力学. 正如不同类型的哈密顿量导致不同物理学，由不同生成模型构造的自由能也导致不同的神经元和行为动力学.

哈密顿物理与主动推断之间的第二个联系来自哈密顿量与概率测度之间更直接的关联. 其思想是将守恒的哈密顿量与系统能量联系起来. 请记住，迄今在本章及第 2 章称为能量的量都具有负对数概率的形式. 这反映了对能量的一种解释：能量只是系统给定构型的不可能程度的度量. 在这一观点下，能量守恒和概率守恒是等价定律. 当通过马尔可夫毯与外部状态耦合的耗散系统向低能量或高概率状态移动时，我们可以直接将能量或哈密顿量与惊异联系起来. 因此，主动推断是应用于特定类型系统，即具有马尔可夫毯的系统的哈密顿物理.

这两种表述之间的第三个关联是支撑能量与动力学关系的变分法. 当哈密顿物理表述为最小作用量原理时，这一点最为明显：作用量指沿路径对拉格朗日量的积分. 关键在于，这一作用量是路径的泛函. 此处路径是时间的函数，其输出是在该时刻沿该路径运动的粒子的位置和速度. 确定性粒子所遵循的路径使这一作用量最小化. 类似地，主动推断建立在信念（其本身是隐状态的函数）必须最小化自由能泛函的思想之上. 关键

[2]译注：原文此处写作牛顿第三定律，但加速度与合力的关系通常对应第二定律；保留原文并记录此疑点.

联系在于，两种情形都必须相对于泛函优化函数：分别是相对于作用量优化路径，或相对于自由能优化信念. 这使两者都处在变分法的范畴内；变分法是数学中致力于寻找泛函极值的分支. 在物理学中，这导出欧拉—拉格朗日方程；在主动推断中，则得到变分推断过程.

3.6 模型、策略与轨迹

在第 3.2 节，我们强调主动推断的适用范围涉及与环境保持一定分离的系统，并看到这体现为马尔可夫毯的存在. 在第 3.3 节，我们指出，这一毯的持续存在需要平均而言最小化感觉状态惊异的动力学. 由于这可以解释为自我证成，我们得出结论：行为由一个稳态分布决定，该分布可以解释为关于感觉数据如何产生的生成模型.

这告诉我们非常重要的一点：每个生成模型都应当与不同类型的行为相关联. 因而，通过指定不同的生成模型，并隐含地指定该系统会发现什么令人惊异，可以解释不同类型的行为. 此外，不同类型的生成模型可能对应具有不同复杂程度的适应性或认知生物（Corcoran et al. 2020）. 驱动图 3.3 中动力学的那类非常简单的生成模型只能提供最基本的认知，因为它们无法考虑其他轨迹或反事实轨迹的可能性. 此外，这些模型是浅层的，只能在一个时间尺度上进行推断. 相比之下，层级生成模型能够在多个时间尺度上进行推断. 在层级或深层模型中，较高层级的动力学一般编码变化较慢的事物，例如我正在阅读的句子，并为较低层级所表征的变化较快的事物，例如我正在阅读的词语，提供背景（Kiebel et al. 2008；Friston, Parr, and de Vries 2017）.

要推导出与能动性和有感知系统相关的更复杂行为，需要在模型中加入什么？一个答案是对不同未来，或事件可能发生的不同方式建模并在其中选择的能力. 而考虑可能的未来需要具有一定时间深度、明确表征行动后果的生成模型. 将其纳入模型，将确保行为符合这些未来中最可能的一种. 考虑这些备选情形的反事实能力，或许是有感知系统相关的稳态与较简单生物的区别所在. 当不同未来涉及我们能够控制的事物时，我们将其称为策略或计划. 正如第 2 章所见，区分这些计划的一种方式是在模型中加入一种先验信念：期望自由能最低的策略最为合理. 这为刻画某类具有马尔可夫毯且处于稳态的系统提供了一种方式；这类系统似乎很好地对应于像我们这样的系统.

3.7 主动推断对能动、控制论和预测理论的协调

通过强调自由能最小化，主动推断统一并扩展了三个表面上互不相连的理论视角.

首先，主动推断与生命和认知的能动理论一致. 这些理论强调行为的自组织以及与环境之间的自创生相互作用，后者确保生物体保持在可接受的界限内（Maturana and Varela 1980）. 主动推断提供一个形式框架，解释生物体如何通过自组织形成马尔可夫毯这一统计结构，以抵抗自身状态的弥散. 马尔可夫毯使生物体与环境能够相互交换，同时又将生物体状态与外部环境动力学分开，并在某种意义上保护其完整性.

其次，主动推断与控制论理论一致，后者将行为描述为有目的的和目的论的. 目的论意味着行为由内部机制调节，该机制持续检验目标是否实现，若未实现则引导纠正行动（Rosenblueth et al. 1943, Wiener 1948, Ashby 1952, G. Miller et al. 1960, Powers 1973）. 类似地，主动推断智能体同时使用知觉和行动来最小化偏好状态与感知状态之

间的差异. 主动推断通过指定实际最小化的是智能体可以测量的统计量——变分自由能——为这一最小化过程提供规范且可行的描述. 在某些条件下，变分自由能对应于预测误差，即预期与感知之间的差异. 这意味着可以将控制论控制表述为一个前瞻过程，引出下一点.

第三，主动推断与将控制描述为依赖环境模型的前瞻过程的理论一致；这一模型可能在大脑中得到物理实现（Craik 1943）. 主动推断假设智能体使用生成模型构造指导知觉和行动的预测，并评估未来和反事实的行动可能性. 这一假设与良好调节器定理一致；该定理指出，任何控制器都应当拥有或成为环境的良好模型（Conant and Ashby 1970）. 主动推断在近似贝叶斯推断及变分和期望自由能最小化的严格刻画下，协调这些基于模型的大脑和行为视角. 此外，主动推断与观念运动理论大体一致（Herbart 1825, James 1890, Hoffmann 1993, Hommel et al. 2001）. 这一理论认为，行动始于想象过程，触发行动的是对行动后果的预测表征，而不是像刺激—反应理论中那样由刺激触发（Skinner 1938）. 主动推断将这一思想置于推断框架中，其中行动源于关于未来的信念；这产生若干含义，例如为触发行动，必须暂时衰减感觉证据，否则这些证据会证伪触发行动的信念（H. Brown et al. 2013）.

协调这些框架很有意思，因为它们常被认为相互冲突. 例如，生物学中自组织和目的论常被视为不相容. 此外，能动理论倾向于淡化表征和控制，而这两者却是大多数基于模型的推断理论的核心构念. 主动推断从一个不寻常的角度形式化适应性智能体的自创生动力学，同时考虑自组织与预测. 通过连接不同视角，主动推断有可能帮助我们理解它们如何相互启发.

3.8 主动推断：从生命出现到能动性

主动推断从第一性原理出发，展开这些原理以解释从最简单到最复杂的适应性和生命系统所表现出的行为与认知. 在简单生物与复杂生物之间的连续谱中，主动推断区分了仅最小化变分自由能的生物与同时最小化期望自由能的生物.

任何主动采样感觉以最小化变分自由能的适应性系统，等价地说，都是主动收集其生成模型证据的智能体，即自我证成智能体（Hohwy 2016）. 这些系统能够通过达到基本稳态调节过程所提供的设定点来避免弥散、自我调节并生存. 它们可以产生复杂多样的行为，也可以具有很高的适合度，病毒已经是明显的例子. 有些系统可能具有层级生成模型，允许推断以不同时间尺度变化的事件：从较低层级较快变化的事件到较高层级较慢变化的事件，因而可以形成应对自身经历的复杂策略. 但这些生物也受到根本限制，因为其生成模型缺乏时间深度，即缺乏明确规划和考虑未来的能力；虽然它们可以隐含地做到这一点，例如作为遗传进化的结果，但它们总是生活在当下.

具有时间深度的生成模型为最小化期望自由能，或用心理学术语说进行规划，打开了大门. 在主动推断中，这不仅仅意味着适应性提高，还意味着至少一种原始形式的能动性. 对适应性系统而言，最小化期望自由能等价于具有一种隐含先验：自己是一个最小化自由能的智能体，但会行动以最小化未来的自由能. 当这一先验信念进入生成模型后，适应性系统就能够形成关于自己未来应如何行动、将遵循哪些轨迹的信念. 换言之，它能够在不同未来之间作出选择，而不是像上述最简单的智能体那样仅选择如何应对当前感知到的情形. 因此，时间深度转化为心理深度. 生物体以何种方式分布在从最简单

到最复杂的适应性系统连续谱上，以及它们能表现出哪些形式的主动推断，是一个经验问题.

3.9 小结

本章的主要内容可以概括如下：生物体必须确保自己只进入其特征状态或偏好状态. 如果将这些偏好状态定义为预期状态，就可以说生物体必须最小化其感觉观测的惊异，并维持最优熵，见框 3.3.

要做到这一点，智能体需要相对于环境动力学保持一定的自主性，并具备一个马尔可夫毯，将其内部状态与环境的外部状态分隔开，即表达两者之间的条件独立性. 马尔可夫毯内的智能体可以与环境进行相互的行动—知觉交换. 这些交换由主动推断理论形式化描述，其中知觉和行动都使惊异最小化. 它们能够这样做，是因为具有一个关于感觉观测如何产生的概率生成模型. 该模型定义了惊异，或者更准确地说，定义了一个可以高效测量和最小化的可处理替代量：变分自由能.

框 3.3：熵最小化与开放式行为

主动推断基于以下前提：生物体努力维持相对有序或负熵、可控性和可预测性，尽管它们沉浸在自然力不断产生涨落并带来持续熵侵蚀威胁的环境中. 这种主动追求秩序最基本的表现是生理稳态调节，其中关键生理参数需要保持在可存活区域内. 然而，熵最小化不应等同于僵硬的反应模式，例如自主稳态反应；情况恰恰相反，尤其是在较高级的生物体中. 我们可以发展新颖行为的开放式集合，以追求原有的稳态命令，例如生产和购买好酒以满足口渴及其他需要. 这有时称为“异稳态”（Sterling 2012）.

更广泛地说，我们主动追求一定的秩序和可控性本身，而不一定涉及某项具体的稳态命令；这或许是因为保持秩序有助于实现许多这样的命令. 我们主动塑造生态位，使其更可预测、更少令人惊异. 这一点体现在我们构建物理空间的方式中，例如避难所和城市提供庇护，免受不受控制的自然力影响；也体现在文化空间中，例如具有法律和义务规范的社会提供庇护，免受无政府状态下社会力量的影响. 在所有这些例子中，为确保熵或惊异长期下降，我们通常需要接受某种短期增加，例如建造新事物或改变社会立场时. 这有助于我们理解：惊异最小化的基本要求并不与认知命令以及寻求新奇、好奇和探索行为相冲突，反而促进它们；我们认为这些行为对许多物种至关重要.

认知命令显现的第一种方式是在变分自由能最小化期间. 自由能的一种分解方式是将其表示为近似后验下的期望吉布斯能减去近似后验的熵. 换言之，智能体在努力增加熵. 这看似矛盾，但如果考虑到这里是智能体近似后验信念的熵，矛盾便消失了. 这可以理解为一个命令：尽可能准确地解释事物，同时“保留选择余地”，除非必要，否则避免承诺任何具体解释，即最大熵原理（Jaynes 1957）.

认知动力学显现的第二种方式是在期望自由能最小化期间；有趣的是，这里存在符号相反的两个熵. 其中包括后验预测熵，即给定选择时对将遇到何种结果的不确定性，它必须最大化，如同变分自由能中关于状态的信念；另一个是给定状态时结果的条件熵，即策略所蕴含的模糊度，它必须最小化. 在最小化变分自由能时，命令是最大化当前信念的熵；在最大化期望自由能时，命令则是选择能够最小化未来信念模糊度的行动.[3]

[3]译注：原文此处写“最大化期望自由能”，与本框前文的“最小化期望自由能”以及前述章节不一致；此

这产生认知、好奇、寻求新奇和信息觅取行为，有助于消除不确定性或改进生成模型，进而长期最小化惊异（Seth 2013；Friston, Rigoli et al. 2015；Seth and Friston 2016；Schwartenbeck, Passecker et al. 2019）.

主动推断智能体看起来在生成模型下进行近似贝叶斯推断，并最大化其模型的证据，即它是一个自我证成智能体. 推断的前瞻性部分通过选择预计将最小化未来自由能的行动过程或策略实现. 这一形式体系从哈密顿最小作用量原理的角度提供了一种关于最优行为的新观点；这项第一性原理将主动推断与统计物理、热力学和非平衡稳态领域联系起来.

处保留原文，待查勘误.

Chapter 4

主动推断的生成模型

一切都应当尽可能简单，但不应过于简单.
—Albert Einstein

4.1 引言

本章以更形式化的处理补充前几章对主动推断的概念性讨论. 具体而言，本章阐述自由能与贝叶斯推断之间的关系、主动推断中通常使用的生成模型形式，以及对这些模型最小化自由能所得到的动力学. 一个重点是时间如何在生成模型中表示. 我们将看到以连续时间表述的生成模型和将时间视为事件序列的生成模型之间的区别. 最后，本章阐述推断性消息传递的思想；这一思想为神经生物学中的重要理论，包括预测编码，提供基础.

4.2 从贝叶斯推断到自由能

在前两章中，我们概述了主动推断与神经科学中其他既有范式之间的一些重要联系. 第 2 章着重讨论了与主动推断最为接近的理论之一——贝叶斯脑概念（Knill and Pouget 2004, Doya 2007）. 它提供了一种有用的方式，使我们从更形式化的视角思考主动推断的一些后果. 具体来说，它帮助我们构造进行主动推断的智能体必须解决的问题. 大体而言，这些问题包括推断世界状态的问题（知觉）和推断行动过程的问题（规划）. 尽管人们容易将贝叶斯最优性等同于精确贝叶斯推断，精确推断通常在计算上难以处理，甚至不可行. 在认知心理学和人工智能应用中，人们常考虑有界形式的推断与理性，我们在第 3 章介绍了一些例子. 在贝叶斯框架下，这意味着使用近似推断. 这些方法包括采样方法和变分方法，而主动推断建立在变分方法之上. 本节回顾贝叶斯推断及其变分形式的基本要素（Beal 2003, Wainwright and Jordan 2008），以期帮助读者直观理解自由能的作用，并强调生成模型在推断世界时的重要性.

本章比第 1–3 章更具技术性，需要用到一些线性代数、微分和泰勒级数展开. 对细节感兴趣或需要复习的读者可查阅附录中的必要背景；不希望深入理论基础的读者可以跳过本章. 全章都会解释各个方程的关键含义，因此即使不跟随形式推导，也应当能够理解这里的重要概念.

一个好的起点是贝叶斯定理. 回顾第 2 章，这一定理表达了先验与似然之积等于后验与边缘似然之积. 式 (4.1) 重现了这一关系：

$$
\begin{aligned}
P(x)P(y \mid x) &= P(x \mid y)P(y), \\
P(y) &= \sum_x P(y, x) = \sum_x P(y \mid x)P(x).
\end{aligned} \tag{4.1}
$$

式 (4.1) 第一行是贝叶斯定理. 第二行表明边缘似然或模型证据 $P(y)$ 可直接由先验和似然计算[1]. 这说明共同构成生成模型的先验和似然足以让我们计算模型证据和后验概率. 尽管如此，计算并不总是容易：式中求和，或处理连续变量时的积分，可能在计算或解析上难以求解. 一种解决方式，也是变分推断的起点，是将这一可能困难的积分问题转换成优化问题. 为理解其工作方式，需要诉诸 Jensen 不等式："平均值的对数[2]总是大于或等于对数的平均值." 图 4.1 直观地展示了其原因.

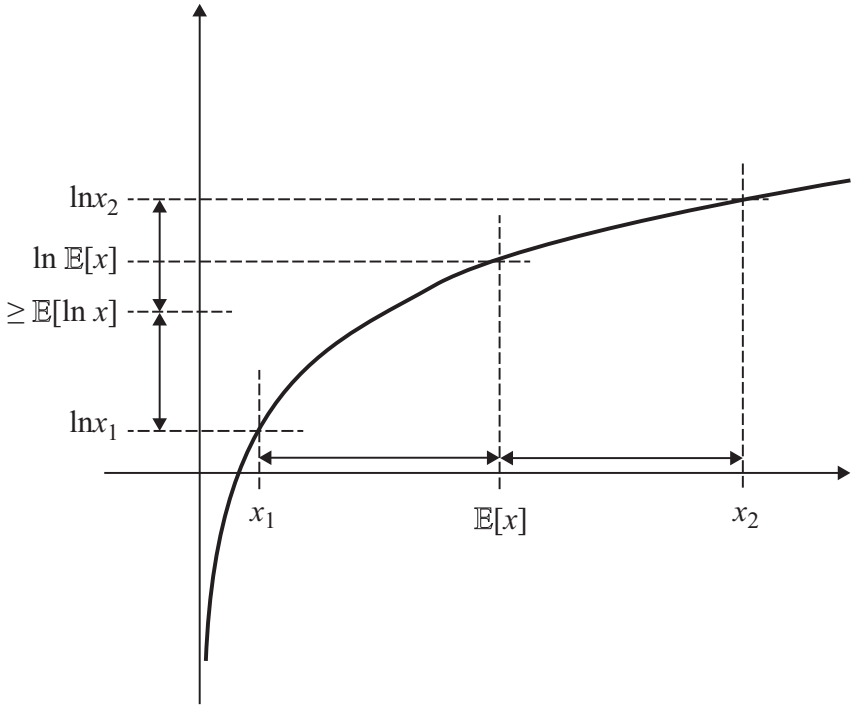


图 4.1: 用对数函数直观说明 Jensen 不等式. 如果只有两个数据点 x_1 和 x_2，我们可以先求它们的平均值 $\mathbb{E}[x]$ 再取对数，也可以先对每个数据点取对数，再求平均 $\mathbb{E}[\ln x]$. 由于对数函数的凹性，后者总是低于前者 $\ln \mathbb{E}[x]$，除非数据点相同，此时平均值的对数等于对数的平均值. 这一不等式对任意数量的数据点成立.

为了利用这一性质，我们可以将式 (4.1) 第二行的求和项乘以一个任意函数 Q 除以其自身，并对两边取对数. 这相当于乘以 1，因此等式仍然成立；从数学上说，这没有改变任何东西. 不过，现在我们可以把表达式解释为两个概率之比的期望[3]，并利用 Jensen 不等式：

$$\begin{aligned}\ln P(y) &= \ln \sum_x P(y,x)\frac{Q(x)}{Q(x)} \\ &= \ln \mathbb{E}_{Q(x)}\left[\frac{P(y,x)}{Q(x)}\right] \geq \mathbb{E}_{Q(x)}\left[\ln \frac{P(y,x)}{Q(x)}\right] \triangleq -F[Q,y].\end{aligned} \tag{4.2}$$

这一方程第二行利用了对数期望这一事实：根据 Jensen 不等式，它必定大于或等于对数的期望. 这一做法有时称为重要性采样. 不等式右侧称为负的变分自由能[4]：自由能越小，就越接近负对数模型证据. 由此，我们可以将贝叶斯定理（式 (4.1)）改写为对数形

式，取其在后验分布下的平均，并揭示这与式 (4.2) 各量之间的关系：

$$\begin{aligned}\ln P(x,y) &= \ln P(y) + \ln P(x \mid y) \quad \Rightarrow \\ \mathbb{E}_{P(x|y)}[\ln P(x,y)] &= \ln P(y) + \mathbb{E}_{P(x|y)}[\ln P(x \mid y)] \\ \mathbb{E}_{Q(x)}[\ln P(x,y)] &= -F[Q,y] + \mathbb{E}_{Q(x)}[\ln Q(x)].\end{aligned} \tag{4.3}$$

第二行成立是因为 y 的对数概率不是 x 的函数，因此取其在后验分布下的期望不会改变这一量. 式 (4.3) 有助于直观理解自由能和 Q 分布的作用；如果没有变分近似，这两个量难以计算. 前者扮演负对数模型证据的角色，而后者的作用仿佛是后验概率. 更形式化地，我们可以像第 2 章那样重排自由能，量化自由能和模型证据之间的关系：

$$\begin{aligned}F[Q,y] &= \underbrace{D_{\mathrm{KL}}[Q(x)\|P(x \mid y)]}_{\text{散度}} - \underbrace{\ln P(y)}_{\text{对数模型证据}}, \\ D_{\mathrm{KL}}[Q(x)\|P(x \mid y)] &= \mathbb{E}_{Q(x)}[\ln Q(x) - \ln P(x \mid y)].\end{aligned} \tag{4.4}$$

式 (4.4) 第一行用 KL 散度和负对数证据表示自由能. 第二行将 KL 散度定义为两个对数概率之差的期望. 它常用来度量两个概率分布彼此有多不同.

有时，使用自由能的动机直接从这一散度出发：如果目标是进行近似贝叶斯推断，就需要找到最匹配精确后验的近似后验. 因此可以选择两者之间的某个散度度量，例如式 (4.4) 中的 KL 散度，并将其最小化. 由于我们不知道精确后验，不能直接使用这一散度. 一个解法是加入对数证据项，使之与对数后验结合形成联合概率；我们知道联合概率，因为它就是生成模型. 其结果便是自由能.

这一视角产生的一个有趣后果是，使用哪种散度度量存在某种不确定性. 如果希望近似后验和精确后验尽可能接近，可以使用交换 Q 和 P 后的另一个 KL 散度，或者从一大类散度中选取；每一种都会强调分布差异的不同方面. 然而，第 3 章阐述的思想突出了自我证成对进行主动推断的系统的重要性. 因此，我们主要寻找的是可处理的证据最大化方案，其次才是最小化散度. 从这一视角看，使用哪种散度度量并无歧义：它由使用 Jensen 不等式而产生.

4.3 生成模型

计算自由能需要三个要素：数据、一族变分分布以及生成模型，后者由先验和似然构成. 本节概述主动推断所用的两类非常一般的生成模型，以及对应每一类模型的自由能形式. 第一类处理关于范畴变量（例如物体身份）的推断，并表述为事件序列；第二类处理关于连续变量（例如亮度对比度）的推断，并使用随机微分方程在连续时间中表述. 在详细指定这些模型之前，我们先回顾表达生成模型所蕴含依赖关系的一种图形形式体系.

图 4.2 展示了几个以因子图表示的生成模型例子，以帮助读者直观理解可以用这种方式表述哪些事物. 图中将生成模型的因子，例如先验和似然，表示为方框，将模型中的变量，即隐状态或数据，表示为圆圈. 箭头表示变量间因果关系的方向. 左上图展示这些模型可以采用的最简单形式：隐状态 x 产生数据 y. 此模型中的先验显示为因子 1，似然显示为因子 2. 其他图通过引入额外变量扩展了这一思想. 在右上图中，z 扮演第二个隐状态的角色，因此 y 同时依赖 x 和 z 的状态.

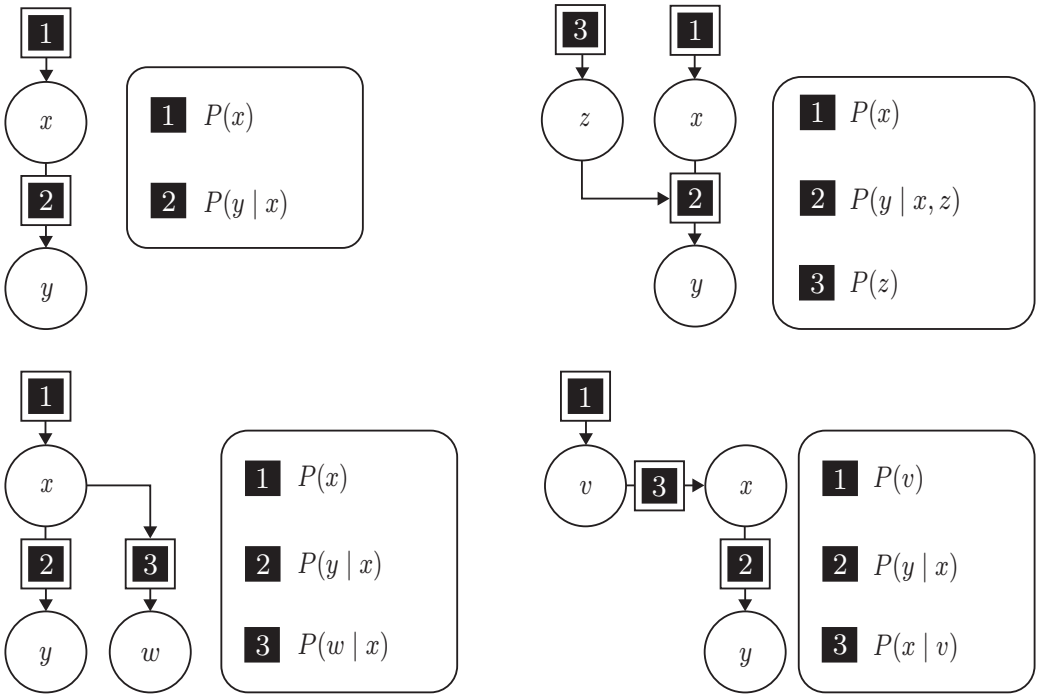


图 4.2: 图形概率模型中变量之间的依赖关系. 圆圈表示随机变量，即我们对其持有信念的事物；方框表示描述这些变量之间关系的概率分布. 从一个圆圈经由方框指向另一个圆圈的箭头，表示第二个圆圈中的变量依赖第一个圆圈中的变量，而且这一依赖由方框所代表的概率分布刻画.

例如，考虑一项临床诊断检测. 此时，左上角的简单图可解释为是否患病 x 和检测结果 y. 先验是疾病的患病率，似然则指定检测的性质，包括特异性，即没有疾病时结果为阴性的概率，以及敏感性，即有疾病时结果为阳性的概率. 因而，我们可以按获得检测结果的机制来理解这一模型，即从因子图顶部向底部进行. 首先，从疾病患病率已知的人群中抽取一个人. 如果此人患病，那么产生真阳性检测结果的概率由检测敏感性给出，否则产生假阴性. 如果此人未患病，那么产生真阴性的概率由特异性给出，否则产生假阳性.

沿用这个例子，可以解释其他因子图. 在右上面板中，x 和 z 可以是两种不同疾病各自的有无，而任意一种都可能产生阳性检测结果. 在左下图中，w 扮演数据的角色；y 和 w 都由 x 产生，例如可以代表对同一疾病过程提供信息的两项不同诊断检测. 最后，右下图将 x 和 v 都视为隐状态，但引入层级结构，其中 v 导致 x，x 导致 y. 此处可以把 v 看作疾病 x 有无的背景或易感因素，例如遗传多态性，而疾病可以通过测量 y 来检测. 原则上，我们可以向这个层级中加入任意数量的变量.

这类生成模型常用于静态知觉任务，例如物体识别或线索整合. 主动推断所用的生成模型有一个重要不同：当新的观测被采样时，它们随时间演化；而加入的观测通过行动依赖于对模型中变量的信念. 这有两个关键含义. 第一，条件依赖关系包括给定时间的隐变量对先前时间隐变量的依赖. 第二，这些模型有时将关于 “我如何行动” 的假设作为隐变量.

图 4.3 以因子图形式（Loeliger 2004, Loeliger et al. 2007）展示主动推断中使用的两种基本动态生成模型（Friston, Parr, and de Vries 2017）. 上图展示部分可观测马尔可夫决策过程（POMDP），其中状态序列 s 随时间演化. 在每个时间步，当前状态以先前时间的状态和当前执行的策略 π 为条件. 这里的策略可视为为可能遵循的不同轨迹或行动序列建立索引. 每个时间点都对应一个观测 o，它只依赖于该时间的状态. 这类模型对于顺序规划任务，例如在迷宫中导航（Kaplan and Friston 2018），或涉及在备选项之间选择的决策过程，例如场景分类（Mirza et al. 2016），非常有用.

图 4.3 下图展示了一个非常相似的图形模型，但以连续时间表示. 这一模型不把轨迹表示为状态序列，而是表示状态 x 的当前位置、速度和加速度，以及后续的时间导数. 这些值称为运动的广义坐标，可用泰勒级数展开重建轨迹；有关这一背景下泰勒级数近似的介绍见附录 A. 此处状态与其时间导数之间的关系依赖于缓慢变化的原因 v，其作用类似于上面的策略. 与先前一样，状态产生观测 y. 记号上的区别，即 s, π, o 与 x, v, y 的区别，用于强调在离散时间演化的范畴变量与在连续时间演化的连续变量之间的区别. 同样，从这里开始，我们使用小写 p 和 q 表示连续变量的概率密度，使用大写 P 和 Q 表示范畴变量的分布. 第 4.4 和 4.5 节将更详细地阐明这些模型，并说明每种情况下自由能的最小化如何导出描述推断过程动力学的一组方程.

4.4 离散时间中的主动推断

本节关注上面概述的离散时间模型. 它对于理解处理范畴推断以及在备选假设之间作出选择的一系列认知过程很重要. 这一形式体系还有助于考察经典的利用—探索问题，并说明主动推断如何解决这一问题.

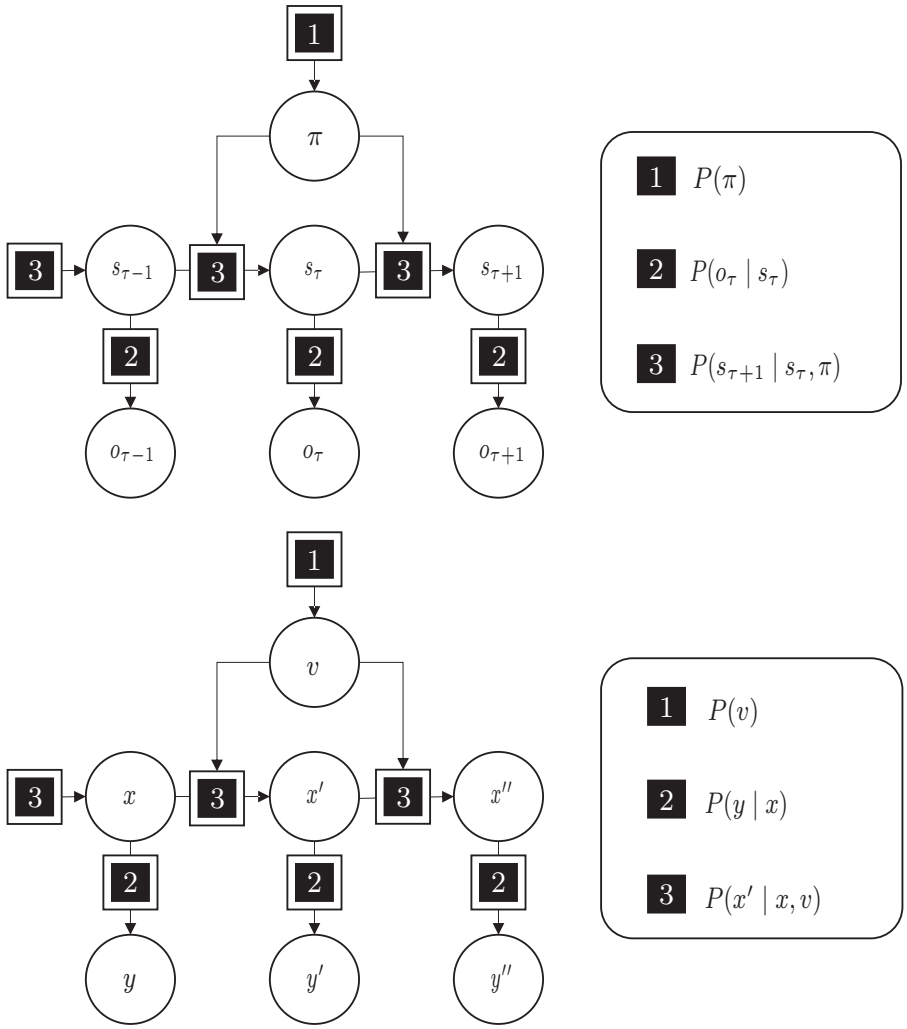


图 4.3: 本书余下部分将使用的两个动态生成模型，采用与图 4.2 相同的图形记号. 上: 部分可观测马尔可夫决策过程（POMDP），由随时间演化的状态序列定义，时间由下标索引. 下：连续时间模型，即随机微分方程所隐含的那类模型，撇号表示时间导数.

4.4.1 部分可观测马尔可夫决策过程

如图 4.3 所示，POMDP 表达依赖策略的隐状态序列随时间的演化. 为形式化地指定这一过程，需要说明图中每个方形因子节点的形式. 我们先描述各个因子，再将它们组合起来，表达构成生成模型的联合分布.

与第 2 章给出的简单贝叶斯规则例子一样，可以将因子分成表示似然的因子和组合起来构成先验的因子. 这里的似然与之前使用的类似，表示给定状态（隐藏的）时结果（可观测的）的概率. 如果结果和状态都是范畴变量，则似然是由矩阵 $\mathbf{A}$ 参数化的范畴分布：

$$\begin{aligned} P(o_\tau \mid s_\tau) &= \mathrm{Cat}(\mathbf{A}), \\ A_{ij} &= P(o_\tau = i \mid s_\tau = j). \end{aligned} \tag{4.5}$$

第二行详细说明了 Cat 记号的含义，即对范畴分布的指定；这对应图 4.3 中标有 “2” 的节点. 隐状态序列（用波浪号表示）上的先验依赖于两个因素：初始状态上的先验，由向量 $\mathbf{D}$ 指定；以及关于某个时间的状态如何转移到下一时间状态的信念，由矩阵 $\mathbf{B}$ 指定：

$$\begin{aligned} P(\tilde{s} \mid \pi) &= P(s_1) \prod_{\tau=1}^{\tau} P(s_{\tau+1} \mid s_\tau, \pi), \\ P(s_1) &= \mathrm{Cat}(\mathbf{D}), \\ P(s_{\tau+1} \mid s_\tau, \pi) &= \mathrm{Cat}(\mathbf{B}_{\pi\tau}). \end{aligned} \tag{4.6}$$

这些共同对应图 4.3 中标有 “3” 的节点. 注意，转移在条件上依赖于所选策略. 因此，可以把式 (4.6) 的先验与式 (4.5) 的似然结合起来，解释为行为序列的一个模型 π. 为了能够在这些模型之间选择，即形成计划，我们需要关于最可能序列的先验信念. 对最小化自由能的生物而言，一个自洽的先验是：最可能的策略是在未来带来最低期望自由能 G 的策略：

$$\begin{aligned} P(\pi) &= \mathrm{Cat}(\boldsymbol{\pi}_0), \\ \boldsymbol{\pi}_0 &= \sigma(-\mathbf{G}), \\ \mathbf{G}_\pi = G(\pi) &= -\mathbb{E}_{\widetilde{Q}}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \tilde{o}, \pi) \| Q(\tilde{s} \mid \pi)]] - \mathbb{E}_{\widetilde{Q}}[\ln P(\tilde{o} \mid C)], \\ \widetilde{Q}(o_\tau, s_\tau \mid \pi) &\triangleq P(o_\tau \mid s_\tau) Q(s_\tau \mid \pi). \end{aligned} \tag{4.7}$$

这一方程对主动推断具有根本重要性，值得更深入地阐明. 前两行表示由 $\boldsymbol{\pi}_0$ 参数化的各策略先验概率与该策略相关的负期望自由能之间的关系. softmax 函数 σ 保证归一化，即确保策略上的概率之和为 1. 式 (4.7) 最后两行表达期望自由能的形式.

注意，这与自由能的泛函形式（式 (4.4)）相似，都包含结果的对数概率和 KL 散度. 关键区别是这里的期望相对于最后一个等式定义的后验预测密度取值. 这一分布表达未来状态和观测的联合概率. 关键在于，这意味着我们能够计算未来的期望自由能；对于依赖当前和过去观测的变分自由能则无法这样做. 此外，注意结果上的分布依赖参数 C，以及 KL 散度的符号发生反转；后者是后验预测概率下取期望的结果. 最后这一点可能

引起混淆，因此值得明确说明原因. 在变分自由能的语境中，KL 散度是近似后验对数概率与精确后验对数概率之差的期望（式 (4.4)）. 期望自由能中相应的项，是近似后验与基于完整结果轨迹所得精确后验之间差异的期望；在此将当前后验信念当作先验. 展开可得：

$$\begin{aligned}
&\mathbb{E}_{\widetilde{Q}}[\ln Q(\tilde{s} \mid \pi) - \ln Q(\tilde{s} \mid \tilde{o}, \pi)] \\
&= \mathbb{E}_{Q(\tilde{o}|\pi)}\left[\mathbb{E}_{Q(\tilde{s}|\tilde{o},\pi)}[\ln Q(\tilde{s} \mid \pi) - \ln Q(\tilde{s} \mid \tilde{o}, \pi)]\right] \\
&= -\mathbb{E}_{Q(\tilde{o}|\pi)}\left[\mathbb{E}_{Q(\tilde{s}|\tilde{o},\pi)}[\ln Q(\tilde{s} \mid \tilde{o}, \pi) - \ln Q(\tilde{s} \mid \pi)]\right] \\
&= -\mathbb{E}_{Q(\tilde{o}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \tilde{o}, \pi) \| Q(\tilde{s} \mid \pi)]].
\end{aligned} \tag{4.8}$$

这里可以看到，取期望的次序很重要. 相对于变分自由能中的对应项，它导致符号反转，构成两种量之间的重要区别. 期望自由能通过选择导致信念发生大幅改变的观测而最小化；相比之下，变分自由能在观测符合当前信念时最小化. 这体现了根据已经获得的数据优化信念（变分自由能最小化）与选择最能优化信念的数据（期望自由能最小化）之间的区别.

这再次表明，主动推断使用两个数学上相关但作用不同且互补的构造：变分自由能 F 和期望自由能 G. 随时间最小化的主要量是变分自由能. 它相对于生成模型优化，而生成模型可以包含策略或行动序列. 与所有其他隐状态一样，智能体需要为策略赋予先验概率，因为策略只是生成模型中的另一个随机变量. 主动推断使用一种先验，粗略地说，它等价于相信自己将在未来最小化自由能，即期望自由能. 换言之，期望自由能提供策略上的先验，因此是最小化变分自由能的前提.

第 2 章说明，与变分自由能一样，期望自由能可以多种方式重排，从而揭示不同解释. 这里我们关注将其解释为与策略相关的风险和模糊度之间的差异. 这与式 (4.7) 等价：

$$\begin{aligned}
G(\pi) &= \underbrace{-\mathbb{E}_{\widetilde{Q}}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \tilde{o}, \pi) \| Q(\tilde{s} \mid \pi)]]}_{\text{信息增益}} \underbrace{-\mathbb{E}_{\widetilde{Q}}[\ln P(\tilde{o} \mid C)]}_{\text{实用价值}} \\
&= \underbrace{\mathbb{E}_{\widetilde{Q}}[H[P(\tilde{o} \mid \tilde{s})]]}_{\text{期望模糊度}} + \underbrace{D_{\mathrm{KL}}[Q(\tilde{o} \mid \pi) \| P(\tilde{o} \mid C)]}_{\text{风险}}.
\end{aligned} \tag{4.9}$$

回顾第 2 章，第一种形式表达了寻求新信息（探索）与寻求偏好观测（利用）之间的权衡. 通过最小化期望自由能，这些项的相对平衡决定行为主要是探索还是利用. 注意，实用价值表现为关于观测的先验信念；可以选择这一分布的参数 C，以反映我们希望刻画的系统类型，即其特征或偏好结果状态. 根据式 (4.9) 第二行，可以把式 (4.7) 改写为

如下线性代数形式：

$$
\begin{aligned}
\boldsymbol{\pi}_0 &= \sigma(-\mathbf{G}), \\
\mathbf{G}_\pi &= \mathbf{H} \cdot \mathbf{s}_{\pi\tau} + \mathbf{o}_{\pi\tau} \cdot \boldsymbol{\varsigma}_{\pi\tau}, \\
\boldsymbol{\varsigma}_{\pi\tau} &= \ln \mathbf{o}_{\pi\tau} - \ln \mathbf{C}_\tau, \\
\mathbf{H} &= -\operatorname{diag}(\mathbf{A} \cdot \ln \mathbf{A}), \\
P(o_\tau \mid C) &= \operatorname{Cat}(\mathbf{C}_\tau), \\
Q(o_\tau \mid \pi) &= \operatorname{Cat}(\mathbf{o}_{\pi\tau}), \qquad \mathbf{o}_{\pi\tau} = \mathbf{A}\mathbf{s}_{\pi\tau}, \\
Q(s_\tau \mid \pi) &= \operatorname{Cat}(\mathbf{s}_{\pi\tau}), \\
Q(s_\tau) &= \operatorname{Cat}(\mathbf{s}_\tau), \qquad \mathbf{s}_\tau = \sum_\pi \boldsymbol{\pi}_\pi \mathbf{s}_{\pi\tau}.
\end{aligned} \tag{4.10}
$$

式 (4.10) 第一行使用 softmax（归一化指数）算子，由期望自由能向量构造总和为 1 的概率分布，其充分统计量为 $\boldsymbol{\pi}_0$. 第二至第四行以线性代数记号表示期望自由能的组成部分. 第五行表明关于观测的先验信念是范畴分布，其充分统计量由向量 $\mathbf{C}$ 给出. 第六至第八行指定线性代数量与相关概率分布之间的关系. 完成生成模型的指定后，现在可以用上述变量表达自由能：

$$
\begin{aligned}
F &= \boldsymbol{\pi} \cdot \mathbf{F}, \\
\mathbf{F}_\pi &= \sum_\tau \mathbf{F}_{\pi\tau}, \\
\mathbf{F}_{\pi\tau} &= \mathbf{s}_{\pi\tau} \cdot (\ln \mathbf{s}_{\pi\tau} - \ln \mathbf{A} \cdot \mathbf{o}_\tau - \ln \mathbf{B}_{\pi\tau} \mathbf{s}_{\pi,\tau-1}).
\end{aligned} \tag{4.11}
$$

这里分解为时间求和，是由于隐含的平均场近似假定近似后验可以分解为因子的乘积：

$$
Q(\tilde{s} \mid \pi) = \prod_\tau Q(s_\tau \mid \pi). \tag{4.12}
$$

在对数形式下，这变成求和，如式 (4.11) 所示. 这种因子分解只是变分推断中众多可能方式之一，代表最简单的选项. 实际上通常会略作调整，详见附录 B.

4.4.2 POMDP 中的主动推断

到目前为止，我们已经定义离散时间生成模型的四个关键要素：似然 $\mathbf{A}$、转移概率 $\mathbf{B}$、关于观测的先验信念 $\mathbf{C}$ 和关于初始状态的先验信念 $\mathbf{D}$. 一旦指定了这些概率分布，就可以使用通用的消息传递方案来最小化自由能并求解 POMDP. 为了推断给定策略下的隐状态，我们将辅助变量 $\mathbf{v}$ 的变化率设为自由能的负梯度；该变量代替对数后验 $\mathbf{s}$. 随后使用 softmax（归一化指数）函数由 $\mathbf{v}$ 计算 $\mathbf{s}$：

$$
\begin{aligned}
\mathbf{s}_{\pi\tau} &= \sigma(\mathbf{v}_{\pi\tau}), \\
\dot{\mathbf{v}}_{\pi\tau} = \boldsymbol{\varepsilon}_{\pi\tau} &\triangleq -\nabla_s \mathbf{F}_{\pi\tau} \\
&= \ln \mathbf{A} \cdot \mathbf{o}_\tau + \ln \mathbf{B}_{\pi\tau} \mathbf{s}_{\pi,\tau-1} + \ln \mathbf{B}_{\pi,\tau+1} \cdot \mathbf{s}_{\pi,\tau+1} - \ln \mathbf{s}_{\pi\tau}.
\end{aligned} \tag{4.13}
$$

式 (4.13) 可视为变分消息传递的一个例子，见框 4.1. 为更新关于策略的信念，我们寻找使自由能最小的后验：

$$\nabla_{\boldsymbol{\pi}} F = 0 \quad \Longleftrightarrow \quad \boldsymbol{\pi} = \sigma(-\mathbf{G} - \mathbf{F}). \tag{4.14}$$

对于最简单形式的 POMDP，式 (4.13) 和 (4.14) 可用于针对任意一组概率矩阵求解主动推断问题；它们可以分别视为描述知觉和规划. 我们将在本书第二部分更详细地阐明这一点，给出用于知觉和规划以及其他认知功能的主动推断计算实例.

图 4.4 以图形方式表示式 (4.10)、(4.13) 和 (4.14)，暗示了大脑中自由能最小化可能的神经元实现方式：可以把节点解释为神经元群体、边解释为突触、消息解释为突触间的信息交换. 后续章节将考虑如何将这一方法扩展到因子分解的状态空间、深层时间模型，以及生成模型本身参数的优化，即学习.

框 4.1：消息传递与推断

马尔可夫毯. 第 3 章介绍了马尔可夫毯的概念，这里值得简要回顾. 它涉及由多个相互作用变量组成的系统. 给定变量的马尔可夫毯由与其相互作用的变量中的一个子集构成. 如果我们了解这个子集的一切，那么子集之外任何事物的知识都不会增加我们对所关注变量的了解. 这里相关的一点是，我们可以根据图形模型中某个变量的马尔可夫毯的局部信息，对该变量进行推断. 变量 x 的毯由导致 x 的变量，即父节点 $\rho(x)$，由 x 导致的变量，即子节点 $\kappa(x)$，以及 x 的子节点的父节点组成. 使用这一记号，两种最常用于近似推断的贝叶斯消息传递方案定义如下.

变分消息传递.

$$\ln Q(x) = \mathbb{E}_{Q(\rho(x))}[\ln P(x \mid \rho(x))] + \mathbb{E}_{\frac{Q(\kappa(x))Q(\rho(\kappa(x)))}{Q(x)}}[\ln P(\kappa(x) \mid \rho(\kappa(x)))].$$

这涉及来自 x 的马尔可夫毯全部组成部分的消息，包括父节点（通过给定父节点时 x 的条件概率）和子节点. 后者依赖于给定 x 的子节点所有父节点时这些子节点的条件概率；这些父节点包括 x. 注意，期望涉及子节点以及子节点的父节点. 由于子节点的父节点包括 x，我们除以 $Q(x)$，以确保期望只包含毯.

信念传播.

$$\begin{aligned}
\ln Q(x) &= \ln \mu_\kappa(x) + \ln \mu_\rho(x), \\
\mu_\kappa(x) &= \mathbb{E}_{\frac{\mu_\kappa(\kappa(x))\mu_\rho(\kappa(x))}{\mu_x(\kappa(x))}}[P(\kappa(x) \mid \rho(\kappa(x)))], \\
\mu_\rho(x) &= \mathbb{E}_{\frac{\mu_\rho(\rho(x))\mu_\kappa(\rho(x))}{\mu_x(\rho(x))}}[P(x \mid \rho(x))].
\end{aligned}$$

这与变分消息传递大体具有相同结构，但使用消息的递归定义，使每条消息依赖其他消息；这里 $\mu_a(b)$ 表示从 a 发给 b 的消息，其他消息则是发给 a 的消息. 这一过程具有方向性：从 a 到 b 的消息依赖所有发给 a 的消息，但来自 b 的消息除外，因此期望中出现除法. 注意，此处期望算子稍不标准的用法使我们能够同时覆盖离散和连续变量，并突出变分消息传递与信念传播之间的形式相似性.

4.5 连续时间中的主动推断

上一节讨论了在特定生成模型选择下主动推断的形式. 这些 POMDP 是表述一系列推断问题的有用方法，包括支撑规划和决策的问题. 然而，当涉及与真实环境相互作

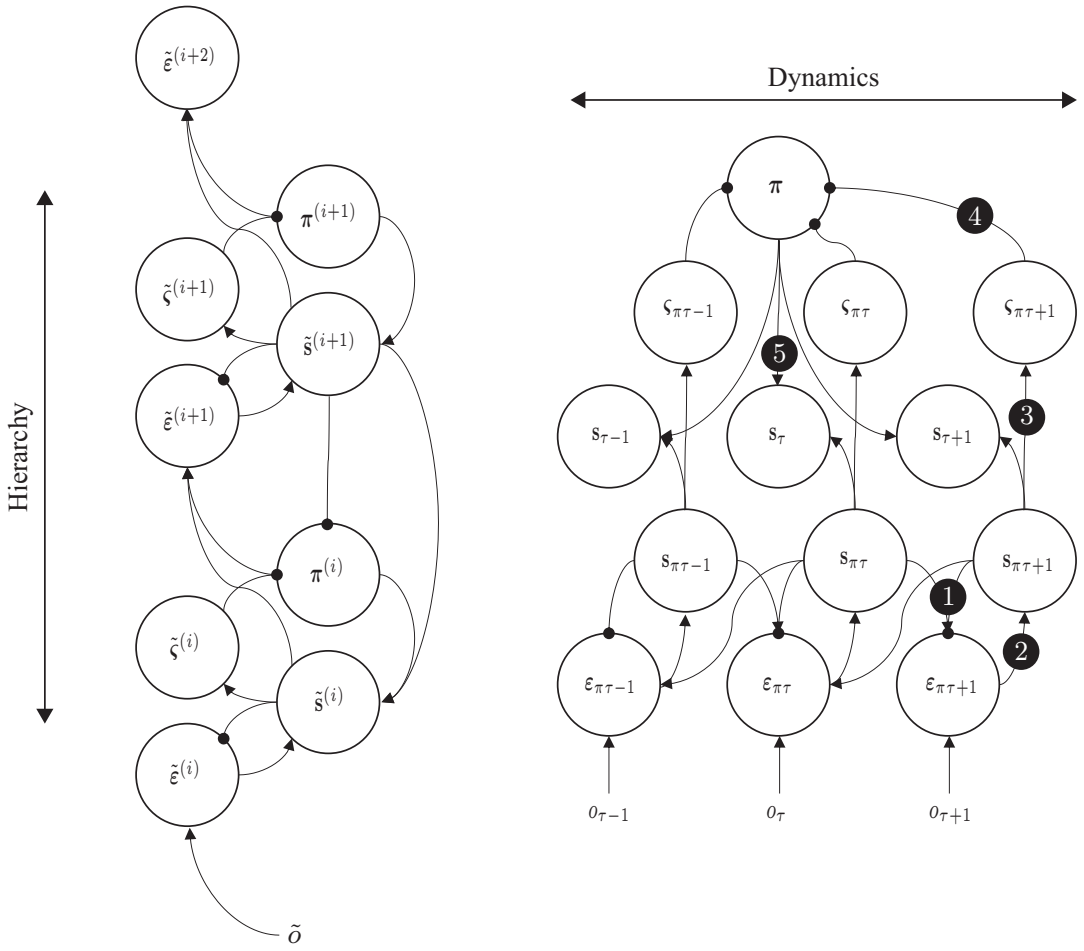


图 4.4: 贝叶斯消息传递. 右：正文所述信念更新方案中不同变量之间的依赖关系. 直观地说，将每个时刻、每种策略下对状态的当前信念与根据其他时刻状态信念所预测的状态（1）及当前结果相比较，计算预测误差. 这些误差驱动信念更新（2）；给定每种策略下对状态的信念，可以计算期望自由能的梯度（3）. 将这些梯度与每种策略下预测的结果（图中略去）结合，计算关于策略的信念（4）. 然后通过贝叶斯模型平均，计算对策略取平均后的状态后验信念（5）. 这一消息传递的高层概述省略了可以加入的某些中间连接，例如连接（4）可展开为明确包含期望自由能的计算. 左：这一方案可以按层级扩展；为简洁起见，此处合并了时间步和策略. 关键思想是，高层网络可以预测低层的状态与策略，并利用它们推断这些状态与策略发生的背景. 第 7 章将进一步阐明这一思想. 图中 Dynamics 和 Hierarchy 分别为动力学和层级.

用时，以范畴变量在离散时间描述的模型便有所不足，因为感觉输入和运动输出是连续演化的变量. 为说明这一点，我们现在转向另一类生成模型，并将完全相同的思想——变分自由能的梯度下降——应用于这些模型，以找到类似的消息传递方案.

4.5.1 预测编码的生成模型

为说明用于连续状态的生成模型形式，我们从下面一对方程出发：

$$\begin{aligned} \dot{x} &= f(x,v) + \omega_x, \\ y &= g(x,v) + \omega_y. \end{aligned} \tag{4.15}$$

第一个方程根据确定性函数 $f(x,v)$ 和随机涨落 ω 表达隐状态随时间的演化；第二个方程表达数据如何由隐状态产生. 在两种情况下都假定涨落服从正态分布，从而得到动力学和似然的概率密度：

$$\begin{aligned} p(\dot{x} \mid x,v) &= \mathcal{N}(f(x,v), \Pi_x), \\ p(y \mid x,v) &= \mathcal{N}(g(x,v), \Pi_y). \end{aligned} \tag{4.16}$$

精度项 Π 是涨落协方差的逆. 这两个方程构成工程学中 Kalman–Bucy 滤波器的生成模型. 然而，此类方案受限于涨落在时间上不相关的假设，即 Wiener 假设. 这不适用于生物系统中的推断，因为涨落本身由动力系统生成，并具有一定平滑性. 我们可以通过不仅考虑隐状态的变化率和数据的当前值，还考虑它们的速度、加速度和后续时间导数，即运动的广义坐标，来处理这一点（Friston, Stephan et al. 2010；见框 4.2）.

框 4.2：运动的广义坐标

运动的广义坐标提供了一种简单参数化，用于表示连续时间中的轨迹. 这一方法基于围绕当前时间的多项式（泰勒级数）展开，得到一个使我们能够外推到近期过去和不久将来的函数. 图 4.5 中的实线表示某个空间中的轨迹 x 随时间 τ 的变化. 从左到右，虚线展示分别用一个、两个和三个坐标，即 x 的连续时间导数所表示的运动广义坐标轨迹. 此处在初始时刻展开；每增加一个广义坐标，就得到对近期未来轨迹更精确的近似. 对大多数应用而言，约六个广义坐标就足够了.

$$\begin{aligned} \dot{x} &= f(x,v) + \omega_x, & y &= g(x,v) + \omega_y, \\ \dot{x}' &= f'(x',v') + \omega_x', & y' &= g'(x',v') + \omega_y', \\ \dot{x}'' &= f''(x'',v'') + \omega_x'', & y'' &= g''(x'',v'') + \omega_y'', \\ &\vdots & &\vdots \\ \dot{x}^{[i]} &= f^{[i]}(x^{[i]},v^{[i]}) + \omega_x^{[i]}, & y^{[i]} &= g^{[i]}(x^{[i]},v^{[i]}) + \omega_y^{[i]}, \\ &\vdots & &\vdots \end{aligned} \tag{4.17}$$

这些广义坐标可以更简洁地概括：再次使用波浪号将轨迹表示为向量，其分量对应于上述连续导数：

$$\left.\begin{aligned} D\tilde{x} &= \tilde{f}(\tilde{x},\tilde{v}) + \tilde{\omega}_x, \\ \tilde{y} &= \tilde{g}(\tilde{x},\tilde{v}) + \tilde{\omega}_y \end{aligned}\right\} \quad \Rightarrow \quad \begin{aligned} p(\tilde{x} \mid \tilde{v}) &= \mathcal{N}(D\cdot\tilde{f}, \tilde{\Pi}_x), \\ p(\tilde{y} \mid \tilde{x},\tilde{v}) &= \mathcal{N}(\tilde{g}, \tilde{\Pi}_y). \end{aligned} \tag{4.18}$$

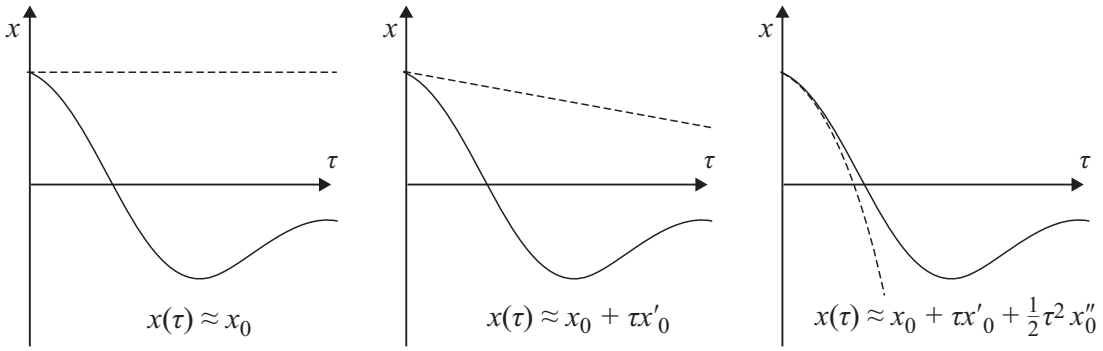


图 4.5: 运动广义坐标的近似，依次保留位置、速度及加速度项；实线和虚线的含义见框 4.2.

式 (4.18) 中，D 是主对角线上方为 1、其余位置为 0 的矩阵. 这实际上将向量的所有元素向上移动，可视为一个导数算子. 可以根据我们对涨落平滑性的假设构造广义精度矩阵，详见附录 B. 如果再引入隐含原因 v 的先验，其重要性将在下文更清楚地显现，就可以写出这个生成模型的自由能：

$$
\begin{aligned}
F[\mu, y] &= -\ln p(\tilde{y}, \tilde{\mu}_x, \tilde{\mu}_v) \\
&= \tfrac{1}{2}\tilde{\varepsilon} \cdot \tilde{\Pi}\tilde{\varepsilon} \\
&= \tfrac{1}{2}(\tilde{\varepsilon}_y \cdot \tilde{\Pi}_y\tilde{\varepsilon}_y + \tilde{\varepsilon}_x \cdot \tilde{\Pi}_x\tilde{\varepsilon}_x + \tilde{\varepsilon}_v \cdot \tilde{\Pi}_v\tilde{\varepsilon}_v), \\
\tilde{\varepsilon} &= \begin{bmatrix} \tilde{\varepsilon}_y \\ \tilde{\varepsilon}_x \\ \tilde{\varepsilon}_v \end{bmatrix} = \begin{bmatrix} \tilde{y} - \tilde{g}(\tilde{\mu}_x, \tilde{\mu}_v) \\ D\tilde{\mu}_x - \tilde{f}(\tilde{\mu}_x, \tilde{\mu}_v) \\ \tilde{\mu}_v - \tilde{\eta} \end{bmatrix}, \\
\tilde{\Pi} &= \begin{bmatrix} \tilde{\Pi}_y & & \\ & \tilde{\Pi}_x & \\ & & \tilde{\Pi}_v \end{bmatrix}.
\end{aligned}
\tag{4.19}
$$

式 (4.19) 中，μ 项表示 x 和 v 对应的近似后验密度的众数. 自由能第一行具有如此简单形式的原因是我们使用了拉普拉斯近似，详见框 4.3. 简言之，这将所有概率密度视为高斯密度；通过泰勒级数展开，这等价于假定我们在分布众数附近运作. 方程第二行用精度加权的预测误差平方表示对数概率，并省略所有相对于后验众数为常数的项. 第三行从对数似然、给定 v 时 x 的对数概率以及 v 的对数先验三个方面展开这一表达式.

4.5.2 作为带运动反射的预测编码的主动推断

在拉普拉斯近似下，近似后验的方差是众数的解析函数，因此我们可以相对于众数优化自由能. 一个简单的理解方式是：我们只需要找到各状态的最大后验（MAP）估计[5]. 这些估计是后验分布的均值，可利用拉普拉斯近似直接配上精度而无需进一步推断，见框 4.3.

框 4.3：拉普拉斯近似

拉普拉斯近似依赖于与框 4.2 所述运动广义坐标类似的原理. 其思想是，可以通过围绕后验众数 μ 的二次展开来近似自由能. 在一维情况下，表达如下：

$$
\begin{aligned}
F[y,q] &= \mathbb{E}_{q(x)}[\ln q(x) - \ln p(y,x)] \\
&\approx \mathbb{E}_{q(x)}\begin{bmatrix} \ln q(\mu) + \underbrace{(x-\mu)\,\partial_x \ln q(x)\big|_{x=\mu}}_{=0} + \frac{1}{2}(x-\mu)^2\,\partial_x^2 \ln q(x)\big|_{x=\mu} \\ -\ln p(y,\mu) - (x-\mu)\,\partial_x \ln p(y,x)\big|_{x=\mu} - \frac{1}{2}(x-\mu)^2\,\partial_x^2 \ln p(y,x)\big|_{x=\mu} \end{bmatrix}.
\end{aligned}
$$

假设二次展开已经足够，等价于说我们可以将概率视为高斯分布，因为高斯密度的对数是二次的. 明确这一点后，可以将上式简化为：

$$
\begin{aligned}
q(x) &= \mathcal{N}(\mu, \Sigma^{-1}), \\
F[y,\mu] &= -\ln 2\pi\Sigma - \ln p(y,\mu) - \tfrac{1}{2}\operatorname{tr}\left[\Sigma\,\partial_x^2 \ln p(y,x)\big|_{x=\mu}\right].
\end{aligned}
$$

在二次假设下，唯一依赖众数的是第二项. 省略其他项便得到式 (4.19). 一旦知道众数，就可以通过以下展开直接找到近似后验的精度：

$$
\begin{aligned}
\ln q(x) &\approx \ln p(x \mid y) \\
&= \ln p(x,y) - \ln p(y) \\
&\approx \ln p(\mu,y) + \underbrace{(x-\mu)\cdot \partial_x \ln p(x,y)\big|_{x=\mu}}_{=0} \\
&\quad + \tfrac{1}{2}(x-\mu)\cdot \partial_x^2 \ln p(x,y)\big|_{x=\mu}(x-\mu) - \ln p(y) \\
&\Rightarrow q(x) \propto e^{-\frac{1}{2}(x-\mu)\cdot\Sigma^{-1}(x-\mu)}, \qquad \Sigma^{-1} = -\partial_x^2 \ln p(x,y)\big|_{x=\mu}.
\end{aligned}
$$

这告诉我们，后验精度就是在后验众数处求值的联合概率的二阶导数.

$$
\begin{aligned}
\dot{\tilde{\mu}} - D\tilde{\mu} &= -\nabla_{\tilde{\mu}} F \\
&= \nabla_{\tilde{\mu}} \ln p(\tilde{y}, \tilde{\mu}) \\
&= -\nabla_{\tilde{\mu}} \tilde{\varepsilon}\cdot \tilde{\Pi}\tilde{\varepsilon}, \\
\begin{bmatrix} \dot{\tilde{\mu}}_x - D\tilde{\mu}_x \\ \dot{\tilde{\mu}}_v - D\tilde{\mu}_v \end{bmatrix} &= \begin{bmatrix} \nabla_{\tilde{\mu}_x}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y - D\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x + \nabla_{\tilde{\mu}_x}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x \\ \nabla_{\tilde{\mu}_v}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y + \nabla_{\tilde{\mu}_v}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x - \tilde{\Pi}_v\tilde{\varepsilon}_v \end{bmatrix}.
\end{aligned} \tag{4.20}
$$

与离散时间方案中见到的梯度下降不同，式 (4.20) 左侧是 μ 的变化率与导数算子作用于它所得结果之差. 原因是，当自由能最小化时，如果与变化率相关的后验众数非零，要求后验众数的变化率为零就没有意义. 换言之，在自由能最小值处，“众数的运动应当是运动的众数”. 这确保自由能最小化时 $\dot{\mu}^{[i]} = \mu^{[i+1]}$.

我们可以在式 (4.20) 基础上更进一步，把隐含原因 v 当作由动力学更慢的更高层级产生的数据，使 v 在较低层级看来不发生变化. 这样，就可以将一系列层级方程连接

起来：

$$\begin{bmatrix} \vdots \\ \dot{\tilde{\mu}}_x^{(i)} - D\tilde{\mu}_x^{(i)} \\ \dot{\tilde{\mu}}_v^{(i)} - D\tilde{\mu}_v^{(i)} \\ \vdots \end{bmatrix} = \begin{bmatrix} \vdots \\ \nabla_{\tilde{\mu}_x^{(i)}} \tilde{g}^{(i)} \cdot \tilde{\Pi}_v^{(i-1)} \tilde{\varepsilon}_v^{(i-1)} - D \cdot \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} + \nabla_{\tilde{\mu}_x^{(i)}} \tilde{f}^{(i)} \cdot \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} \\ \nabla_{\tilde{\mu}_v^{(i)}} \tilde{g}^{(i)} \cdot \tilde{\Pi}_v^{(i-1)} \tilde{\varepsilon}_v^{(i-1)} + \nabla_{\tilde{\mu}_v^{(i)}} \tilde{f}^{(i)} \cdot \tilde{\Pi}_x^{(i)} \tilde{\varepsilon}_x^{(i)} - \tilde{\Pi}_v^{(i)} \tilde{\varepsilon}_v^{(i)} \\ \vdots \end{bmatrix},$$

$$\begin{bmatrix} \tilde{\varepsilon}_x^{(i)} \\ \tilde{\varepsilon}_v^{(i)} \end{bmatrix} = \begin{bmatrix} D\tilde{\mu}_x^{(i)} - f^{(i)}(\tilde{\mu}_x^{(i)}, \tilde{\mu}_v^{(i)}) \\ \tilde{\mu}_v^{(i)} - g^{(i+1)}(\tilde{\mu}_x^{(i+1)}, \tilde{\mu}_v^{(i+1)}) \end{bmatrix}, \qquad \tilde{\varepsilon}_v^{(0)} \triangleq \tilde{\varepsilon}_y. \tag{4.21}$$

图 4.6 以图形方式强调隐状态 x 将同一层级内的时间导数联系起来，以及隐含原因 v 将不同层级联系起来的作用. 在这一预测编码方案中（Rao and Ballard 1999, Friston and Kiebel 2009），较高层级向较低层级发送下行预测；后者计算这些预测中的误差，再将误差沿层级向上传递以更新信念.

为完成主动推断背景下对预测编码的概述，还需要纳入行动. 既然目标是最小化自由能，而行动的后果是改变感觉数据，便有：

$$\begin{aligned} \dot{u} &= -\nabla_u F \\ &= -\nabla_u \tilde{y}(u) \cdot \tilde{\Pi}_y \tilde{\varepsilon}_y. \end{aligned} \tag{4.22}$$

这一方程说明我们通过行动最小化自由能，而且自由能中唯一直接依赖行动的部分是最低层的预测误差. 换言之，行动通过最小化行动的预测与观测感觉后果之间的误差，来实现关于数据的下行预测. 一种理解方式是，仿佛我们在预测编码方案的最低层级加入了经典反射弧（Adams, Shipp, and Friston 2013）. 在这种情况下，主动推断就是预测编码加反射弧. 从神经生物学视角看，其思想是感觉传入纤维进入脑干或脊髓，并与运动神经元形成突触. 对感觉输入的下行预测从皮层传递到运动神经元，后者的输出依赖皮层输入与感觉输入之间的差异.

从计算视角看，反射弧是最简单的控制器形式之一，用于纠正预测与观测的本体感觉信号之间的偏差. 更复杂的运动行为需要生成一系列预测，再利用反射弧按顺序实现它们. 这一机制使主动推断区别于生物运动控制的其他方案，例如不基于预测编码、使用逆模型和比反射弧更复杂的控制器的最优控制（Friston 2011）. 主动推断另一个独特特点是，它不再使用最优控制和强化学习中的价值或代价概念；这些概念完全被通常表达能力更强的先验概念吸收，进一步讨论见第 10 章.

4.6 小结

本章概述支撑主动推断的基本形式思想. 需要把握的关键信息是，近似贝叶斯推断可以表述为最小化一个称为变分自由能的量. 这一量依赖生成模型，该模型表达我们关于数据如何产生的信念. 我们考察了两种生成模型的形式，可以根据所研究的推断问题，尤其是关注范畴变量还是连续变量，选择使用. 对任一模型，自由能最小化的解都可以从神经元群体之间的消息传递角度加以阐明，包括由连续模型得到的广义预测编码方案. 最后，我们指出，不仅可以通过改变信念使其与数据一致来最小化自由能，也可以作用于世界，使数据与信念更一致. 在后续章节中，我们将使用这里引入的形式体系并应用于更具体的情形，从而探索这里阐述的广泛概念的扩展.

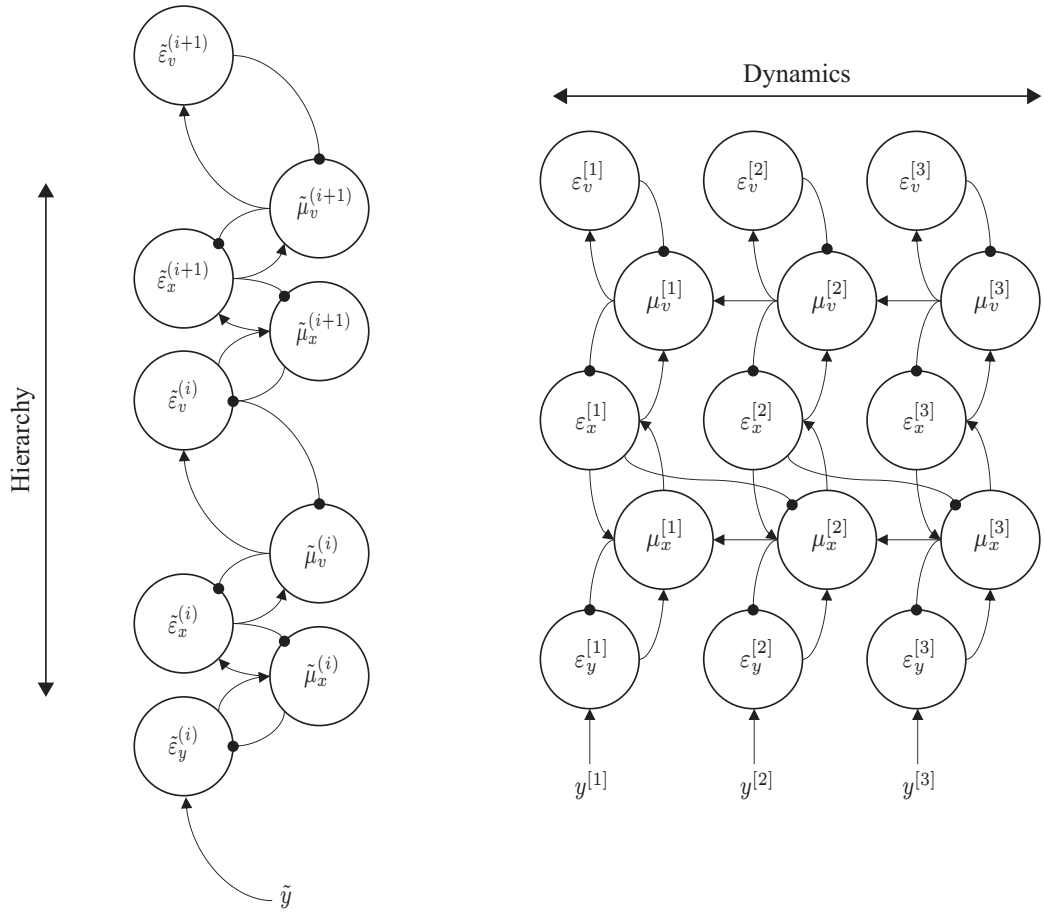


图 4.6: 广义预测编码方案的消息传递. 左: 根据感觉数据计算预测误差, 展示误差如何沿层级向上传播. 较高层向较低层发送预测, 后者可以将预测与感觉数据比较来计算误差. 右: 层级中的单层说明表示不同阶广义运动的神经元群体如何相互作用. 图中 Dynamics 和 Hierarchy 分别表示动力学和层级.

Chapter 5

消息传递与神经生物学

基本上，动物有两类：动物，以及没有大脑的动物；它们叫作植物. 它们不需要神经系统，因为它们不会主动移动，不会在森林大火中拔起根来逃跑！任何主动移动的东西都需要神经系统，否则它很快就会死去.[4]

—Rodolfo Llinas

5.1 引言

第 4 章展示了变分推断对两类生成模型所采取的形式. 本章关注由这些推断动力学产生的过程理论，即解释大脑如何可能实现变分推断的理论. 实现贝叶斯信念更新的核心是贝叶斯消息传递的概念，它包括信念传播和变分消息传递等方案. 这些方案的基本思想是：并非所有事物都直接依赖其他一切事物；相反，生成模型中的每个变量只依赖相对少数的其他变量. 类似地，大脑具有稀疏连接结构，其中任何神经元的活动只依赖与其具有突触连接的神经元. 本章关注如何将变分推断相关的稀疏消息传递映射到生物计算的稀疏连接结构上.

让我们暂时从第 4 章的技术材料退后一步，关注伴随主动推断的过程理论. 有必要区分一项原理，即最小化自由能，与关于这一原理如何可能在大脑等特定系统中实现的过程理论. 后者使我们能够提出可由经验数据检验的假设. 为探讨主动推断如何可能在大脑中体现，我们将第 4 章末看到的消息传递等同于突触通信，并将梯度下降的动力学等同于神经元活动. 本章有两个目标：向具有技术背景的读者介绍主动推断的神经生物学，并向生物学家突出理论与实践神经科学的相关性. 我们强调，本章并非主动推断过程理论的最终定论（Pezzulo, Rigoli, and Friston 2015, 2018；Friston and Buzsaki 2016；Friston and Herreros 2016；Friston, FitzGerald et al. 2017；Friston, Parr et al. 2017；Parr and Friston 2018b；Parr, Markovic et al. 2019），它只是目前看来与可得证据最一致的解释. 我们的目标也不是支持某一种特定过程理论，而是说明如何运用第 1–4 章提出的思想来构造可由神经生物学测量检验的假设.

本章结构如下. 首先，第 5.2 节讨论皮层微环路的作用. 皮层微环路是由数个相互连接的神经群体组成的功能单元，其连接模式在许多皮层区域中重复. 我们突出这一模式化环路与图 4.4 和图 4.6 的消息传递架构之间的关系；这些架构本身也在不同层级上重复. 第 5.3 节转向效应器系统以及主动推断下运动控制的表述，讨论运动皮层如何调节脊髓和脑干反射弧以产生目的性行为. 第 5.4 节涉及丘脑和基底神经节等皮层下结构，它们在规划和决策中具有重要作用. 接着，第 5.5 节考虑突触效能的调节，包括神经递质在精度优化中的作用和可塑性变化在学习中的作用. 最后，第 5.6 节回到层级主题以

[4]译注：引文中的植物分类及关于主动运动与神经系统的普遍表述按原文保留；其科学适用性需另行核查.

及决策与运动生成之间的关系.

5.2 微环路与消息

第 4 章表明，介导变分推断的信念更新方程可以用神经元网络来解释. 所给出的连续模型与范畴模型推断方案各自产生一种模式化环路，其结构在层级生成模型中重复. 类似地，大脑皮层的架构也具有模式化结构（Shipp 2007）. 新皮层分为六层，从浅层（靠近大脑表面）到深层（更接近皮层下白质）编号. 每一层都以特定细胞类型和连接模式为特征（Zeki and Shipp 1988, Felleman and Van Essen 1991, Callaway and Wiser 2009）；图 5.1 中的单个皮层柱示意图概括了这些连接.

大脑某个区域的皮层柱与其他区域的皮层柱及皮层下结构相连. 皮层区域通常被描绘为一个层级，其中粗略而言，最接近感觉输入或运动输出的区域位于层级最低处. 随着我们离开这些区域，例如从初级视觉皮层到次级视觉皮层，就沿层级向上移动. 这一层级概念以图 5.1 所示的层特异性连接结构为依据. 来自较低皮层区域或感觉性初级丘脑核的上行投射，即连接，倾向于指向第 IV 层的有棘星形细胞. 较低皮层区域的上行连接源自其浅层锥体细胞，即第 II、III 层. 来自较高皮层区域的下行投射源自深层，即第 VI 层锥体细胞，并指向较低区域的浅层和深层. 此外，第 V 层深层锥体细胞（Betz 细胞）投射到各种其他目标，包括基底神经节、次级丘脑核等皮层下核团和脊髓运动神经元.

图 5.1 中间的示意图展示了从预测编码网络（图 4.4）到皮层分层解剖结构的一种可能映射（Friston, Parr, and de Vries 2017）. 这有些复杂，但关键点如下：到达第 IV 层有棘星形细胞的上行输入与隐含原因的预测误差 $\tilde{\varepsilon}_v^{(i)}$ 相关. 来自第 III 层浅层锥体细胞的上行输出，为层级中的下一层表示同一预测误差 $\tilde{\varepsilon}_v^{(i+1)}$. 下行输入表示来自更高层的预测 $\tilde{g}^{(i+1)}$，下行输出则是发给较低层的预测 $\tilde{g}^{(i)}$. 在最低层，可以看到来自第 V 层的下行预测，这与左图所示到脊髓运动神经元的输出一致. 我们将在第 5.3 节回到这一点. 回顾第 4 章，隐含原因的作用是将运行于多个不同时间尺度的模型的不同层级联系起来；相比之下，隐状态的作用体现在特定时间尺度的动力学中，这与它们在图 5.1 内部，即柱内连接中的作用一致.

消息传递的不对称性很重要，因为它对上行与下行活动的差异提供经验预测. 其中一个预测是，这些消息可能由不同时间频率的神经活动传递. 原因是从期望计算预测误差所需的运算是非线性的（Friston 2019b）. 这种非线性源于使用非线性函数 g 计算预测；这些函数倾向于提高信号频率，例如正弦波平方后频率加倍. 由此得到的预测是：来自误差单元的上行消息可能在比来自期望单元的下行消息更高的频段中被测量到，见图 5.2. 这与测得的频谱不对称性一致：上行连接通常与伽马频段相关，而下行连接与阿尔法或贝塔频段相关（Arnal and Giraud 2012；Bastos, Litvak et al. 2015）.

图 5.1 右侧的示意图展示了将 POMDP 模型的消息传递解释为皮层微环路的一种方式. 它的结构与预测编码架构相似：期望 s 由浅层和深层锥体细胞表示，并沿皮层层级上下传递. 此外，第 IV 层的误差单元 ε 接收上行信号. 与预测编码式架构不同，区域之间传递的消息是期望的混合，而不是误差（Friston, Rosch et al. 2017；Parr, Markovic et al. 2019）. 然而，通过更新期望来最小化误差，即自由能梯度的总体结构仍得到保留. 这一消息传递区分以某个策略为条件的期望（下标 π）与在策略上取平均的期望. 为

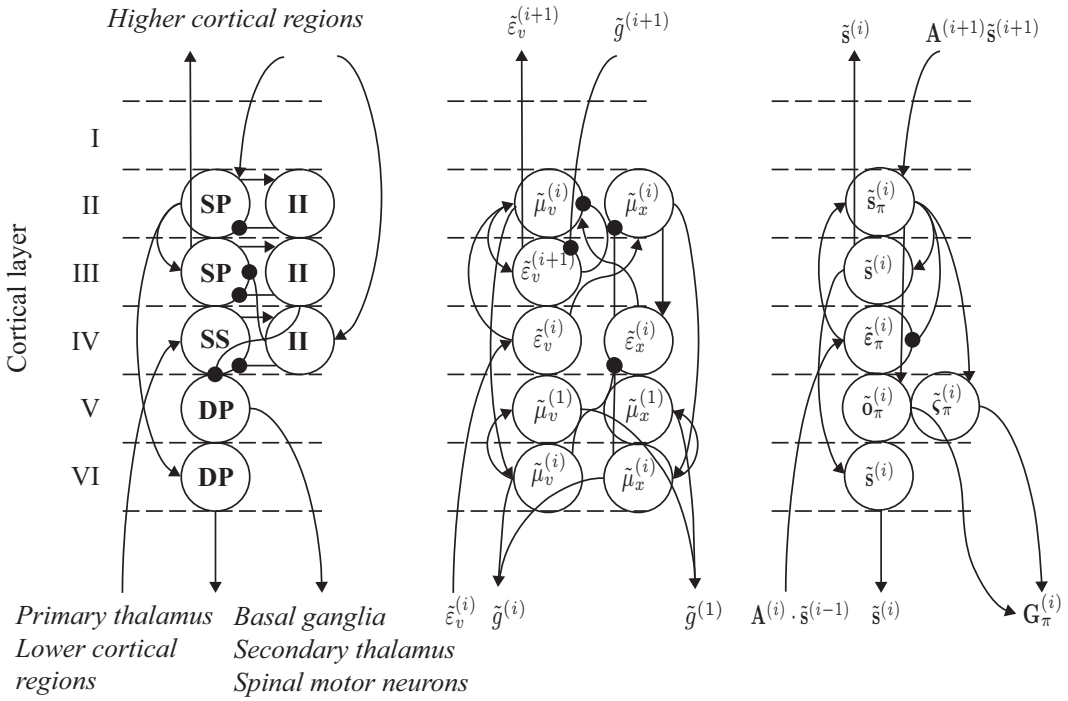


图 5.1: 典型皮层微环路，说明推断性消息传递与大脑皮层架构之间的关系. 左：基于 Miller 2003；Haeusler and Maass 2007；Shipp 2007, 2016；Bastos et al. 2012 综合整理的简化示意图，相关神经解剖观察的概要见这些论文. 圆形箭头端表示抑制，普通箭头端表示兴奋性连接. 神经群体大致分为浅层锥体细胞（SP）、深层锥体细胞（DP）、有棘星形细胞（SS）和抑制性中间神经元（II）. 中：支撑层级预测编码的消息传递. 右：求解部分可观测马尔可夫决策过程（POMDP）所需的消息传递. 图中 Cortical layer 为皮层层次，Higher / Lower cortical regions 为较高 / 较低皮层区域，Primary / Secondary thalamus 为初级 / 次级丘脑，Basal ganglia 为基底神经节，Spinal motor neurons 为脊髓运动神经元.

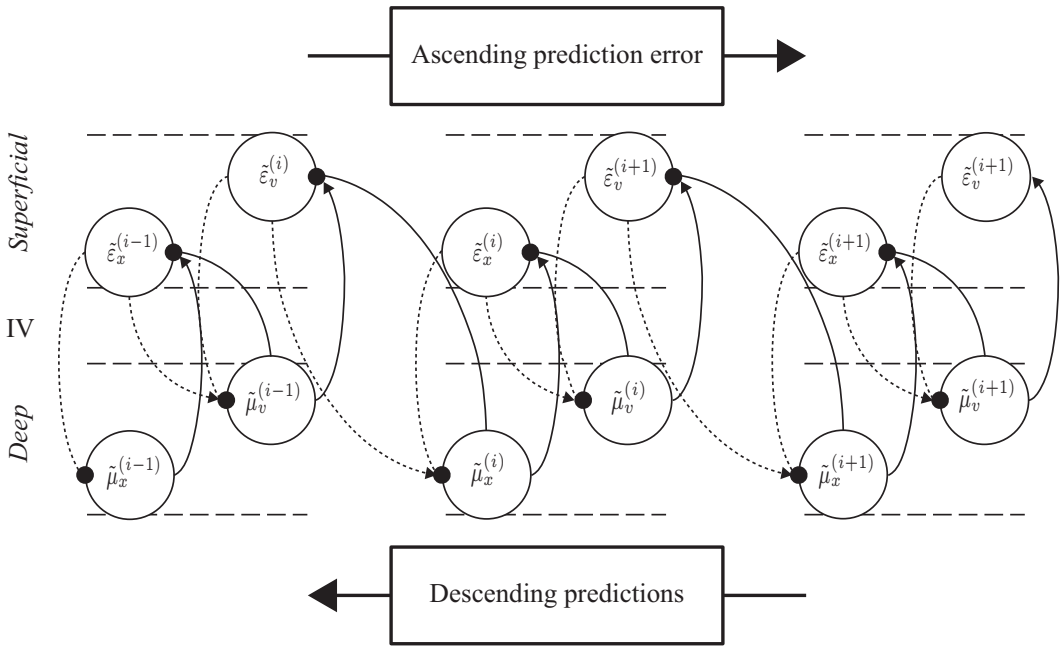


图 5.2: 图 5.1 中间预测编码方案的简化版本，展开以显示三个皮层区域之间的消息传递. 图中突出消息传递的不对称性：虚线显示上行消息，即预测误差；实线显示下行消息，即预测. 图 5.1 是更细粒度的版本，包括这里多突触连接中的中间神经元. 在本图中，将层特异性粗粒化并以第 IV 层为界将皮层分成浅层和深层，就得到许多读者熟悉的预测编码方案. Ascending prediction error 为上行预测误差，Descending predictions 为下行预测，Superficial 与 Deep 分别为浅层和深层.

从前者转换为后者，还需要关于策略的后验信念 π. 我们将在第 5.4 节回到这一点；现在值得强调的是，这一消息传递与可能计算这些信念的皮层下结构指向皮层浅层这一事实相一致.

注意，图 5.1 左侧架构与中间和右侧消息传递方案之间并不存在一一映射. 例如，中图与左图似乎有一处差异：左侧皮层柱中的下行输入到达第 II 层和第 IV 层，而中图中的下行输入则指向第 III 层. 这表明消息传递方案所隐含的连接不一定表现为单个突触. 指向第 III 层的下行抑制性连接，可以由投射到第 IV 层抑制性中间神经元的兴奋性连接，与这些中间神经元投射到第 III 层的连接共同介导. 这一双突触路径消除了两种架构之间表面上的差异.

第 5.3 和 5.4 节分别讨论第 V 层神经元在运动和规划中的作用，对应它们分别向脊髓或脑干及皮层下结构的投射. 第 5.5 和 5.6 节讨论神经消息传递如何随时间调制，然后回到范畴与连续推断微环路之间的关系.

5.3 运动指令

图 5.1 左侧示意图表明，皮层第 V 层投射到脊髓锥体神经元，这可以解释为一种预测（Adams, Shipp, and Friston 2013）. 图 5.3 进一步说明了这一点，展示了该环路的脊髓组成部分：我们看到一个基于初级运动皮层第 V 层 Betz 细胞所编码期望的预测. 到达脊髓背角的本体感觉输入减去这一预测，产生本体感觉预测误差. 这一误差驱动肌肉活动，使误差自身受到抑制，因为本体感觉数据会改变以符合预测. 将运动指令视为预测的思想是主动推断的核心，因为它突出了行动与知觉的二重性. 行动部分通过改变数据来最小化预测与感觉数据之间的任何差异. 这意味着，产生运动所需的唯一东西应当是：如果执行该运动，预计会产生何种感觉后果的预测. 本体感觉预测误差总能通过反射而非信念更新消除，这一事实为初级运动皮层第 IV 层颗粒细胞稀少提供了一种可能解释（Shipp, Adams, and Friston 2013）.

这类运动控制的一个重要方面是感觉衰减的概念（Brown et al. 2013）. 考虑启动一个新运动的问题：为此，我们需要能够预测自己正在运动. 然而，在我们真正运动之前，现有本体感觉数据与这一假设相矛盾，可能促使我们修正假设. 因此，我们需要一种方式防止感觉数据更新期望，以便能够持有自己正在运动这一最初为假的信念，使之通过行动得以实现，可与观念运动现象比较. 这意味着我们需要通过调低本体感觉数据的增益，将注意力从这些数据上移开. 技术上，这一增益由预测这些数据的精度，即方差的倒数，给出. 为使其衰减，需要下行运动束不仅预测数据本身，还要预测这些数据的精度或对数据的置信度，并通过降低这一精度来启动运动. 这称为感觉衰减，可以视为感觉注意的补充，使我们能够忽略某些预测误差，例如扫视眼球运动产生的误差；此时感觉衰减称为扫视抑制. 人们认为，衰减失败是多种神经和精神综合征的核心，包括被动体验现象（Pareés et al. 2014），以及在极端情况下精神分裂症中的紧张状态和帕金森病中无法启动运动的现象.

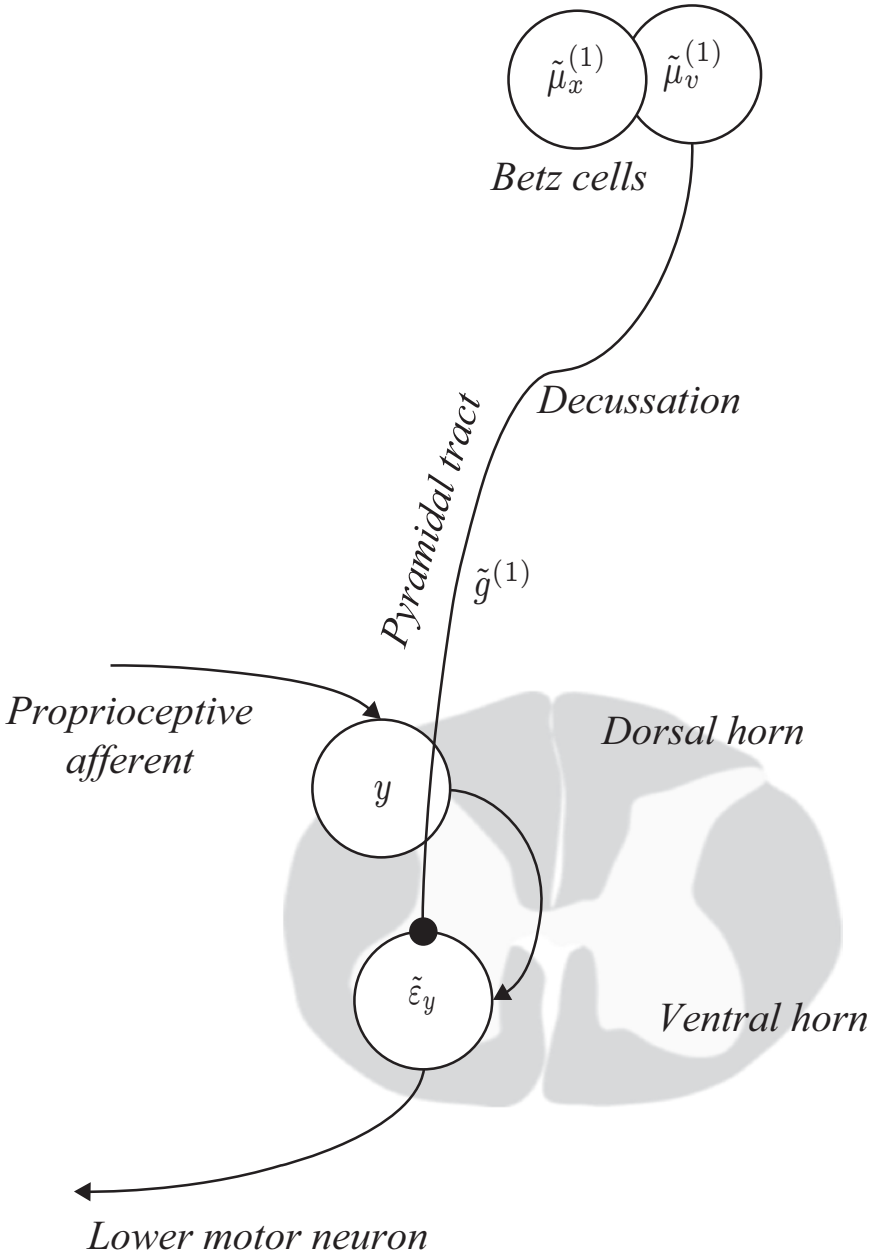


图 5.3: 主动推断调节脊髓运动反射所涉及的神经解剖. 从运动皮层第 V 层的 Betz 细胞，即上运动神经元出发，锥体束携带运动皮层期望所蕴含的运动下对本体感觉输入的预测. 这一束发生交叉，并与脊髓腹角的下运动神经元形成突触，有时通过多个突触连接. 到达脊髓背角的本体感觉传入信号减去预测，得到一个误差，指示满足预测需要多少肌肉收缩. 下运动神经元随后引发肌肉收缩或放松，确保所得本体感觉数据与下行预测相匹配. 图中 Betz cells 为 Betz 细胞，Decussation 为交叉，Pyramidal tract 为锥体束，Proprioceptive afferent 为本体感觉传入，Dorsal / Ventral horn 为背角 / 腹角，Lower motor neuron 为下运动神经元.

5.4 皮层下结构

除投射到脊髓外，皮层第 V 层还指向其他若干结构，其中之一是纹状体（Shipp 2007, Wall et al. 2013）. 纹状体位于大脑深部，由尾状核和壳核组成，是称为基底神经节的复杂结构网络的输入核团. 中型棘状神经元（medium spiny neurons）是纹状体的功能单元，接收来自皮层的输入，并投射到基底神经节的其他核团. 这些细胞分为两类：表达 D1 多巴胺受体的细胞和表达 D2 受体的细胞；多巴胺增强前者的活动，并减弱后者的活动. 前一类细胞是穿过基底神经节的直接通路的起点，经由一个抑制性突触连接到输出核团，即苍白球内节和黑质网状部. D2 细胞形成间接通路，其路径略复杂，包括两个抑制性突触和一个兴奋性突触. 纹状体抑制苍白球外节，后者又抑制丘脑底核（STN）. STN 投射到基底神经节的输出核团，这意味着输出核团受到直接通路的抑制，并经间接通路去抑制.[5] 由于这些输出核团本身具有抑制性，激活表达 D1 的纹状体神经元的净效应是对行为去抑制，而表达 D2 的神经元则会抑制行为（Freeze et al. 2013）.

既然我们已将本体感觉预测与投射到脊髓的通路联系起来，那么应把哪些消息与第 V 层投射到纹状体的通路联系起来？图 5.1 提供了一种可能的答案. 这一层中显示了预测结果 o 以及偏好结果与预测结果之间的差异 ς；二者相结合，用于计算某一策略的期望自由能 G. 在纹状体中计算后者，与基底神经节参与规划，即评估不同备选行动方案的观点一致. 图 5.4 展示了将策略评估的消息传递映射到基底神经节解剖结构的一种可能方式.

图 5.4 的要点是：如第 4 章所述，策略的后验概率 π，在此图中位于苍白球内节，是根据策略的期望自由能计算的. 这一模式沿直接通路从皮层经过纹状体到达基底神经节的输出核团. 然而，还有一些需要细分之处. 在图 4.4 左侧的层级方案中，我们看到较高层级状态的期望可以影响对较低层级策略的信念. 图 5.4 左侧展示了这一点：较高层级状态下的期望观测用于形成经验先验 E，后者可独立于期望自由能而影响策略选择. 第 7 章将回到这一点；其基本思想是，我们对于自己在特定情境中的行动方式持有信念. 当再次处于同一情境时，这些先验期望往往会使策略评估产生偏向，很像习惯的形成. 从这个意义上说，E 和 G 的影响可以分别看成习惯驱动和目标导向驱动. 在强化学习中（Lee et al. 2014），二者有时被称为 “无模型” 系统和 “基于模型” 的系统[1]. 将二者与基底神经节的直接和间接通路联系起来，会产生一个有趣的推论：多巴胺调节这两者之间的平衡. 回顾前文，多巴胺倾向于促进直接通路以及特定策略的执行（Moss and Bolam 2008）；这些策略很可能就是期望自由能最低的策略. 相反，可以预期较低水平的多巴胺会偏向间接通路中对情境敏感的先验；该通路的作用是在给定情境下抑制不合理的策略. 从某种意义上说，纹状体多巴胺可以看成在调节推断 “做什么” 和 “不做什么” 之间的平衡（Parr 2020）.

上述观点与多巴胺能系统受到扰动时的现象相符：在严重帕金森病中，多巴胺耗竭引起运动不能，即无法执行特定策略；而外源性多巴胺激动剂促进冲动性行为（Frank 2005；Galea et al. 2012；Friston, Schwartenbeck et al. 2014）. 它也与基底神经节功能的概念模型一致. 例如，Nambu（2004）提出，直接通路介导对苍白球内节快速而集中的抑制，随后出现广泛而缓慢的兴奋；二者分别导致基底神经节靶结构的兴奋和抑制.

[5] 译注：此处依原文 disinhibited 译为 “去抑制”. 前文所述间接通路经 STN 的兴奋性投射作用于输出核团；其净效应与这里 “去抑制” 这一措辞的关系需结合原作者约定或勘误核查，译文未静默改写.

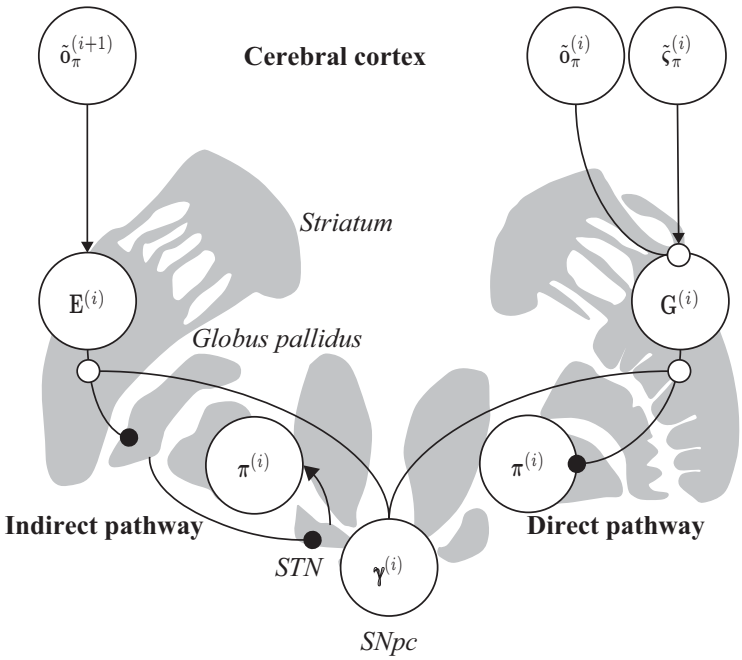


图 5.4: 使用 POMDP 生成模型时，与主动推断有关的策略选择消息传递穿过基底神经节的直接和间接通路. 从大脑皮层出发的通路最终实现对策略的估计. 直接通路（右）从皮层经过纹状体到达苍白球内节. 间接通路（左）从皮层依次经过纹状体、苍白球外节、丘脑底核（STN），到达苍白球内节. 两侧都存在这两条通路；此外，图中还显示黑质致密部（SNpc）调节两者之间的平衡. 注意，这是基底神经节连接结构的简化. 图中 Cerebral cortex 为大脑皮层，Striatum 为纹状体，Globus pallidus 为苍白球，Indirect / Direct pathway 为间接 / 直接通路.

据认为，这可以确保形成一种 “中心—周围” 模式，以高度特异的方式促进运动程序. 这与以下观点相符：计算期望自由能的快速过程促进动作，而传递经验先验的较慢通路则提供更广泛的情境化作用.

关于图 5.4，最后要指出的是，皮层层级中有两个层次，通过上标表示，共同作用于同一个基底神经节环路. 这提示，动力学较慢的区域指向间接通路神经元，而直接通路同时受到快、慢两方面的影响. 随着沿皮层层级向上移动，神经元倾向于表示较慢的动力学. 例如，我们可以预期额叶皮层区域表示的时间尺度长于顶叶区域. 这与通向基底神经节各通路的皮层输入的解剖分布一致（Wall et al. 2013）. 间接通路中的这种时间粗粒化还伴随着空间上的粗粒度；相比之下，直接通路的中型棘状神经元具有更大的树突分支结构（Gertler et al. 2008），从而能够进行更精细的调谐. 因此，图 5.4 中的解剖结构得到临床病理，例如帕金森综合征，以及细胞形态两方面证据的支持.

除基底神经节外，许多其他重要的皮层下结构也参与神经元消息传递. 下一节将讨论神经调质系统起源的那些结构；本节最后简要谈谈丘脑. 我们无法充分论述这一极其复杂的结构，但可以概述一些基本原理. 丘脑通常分为初级核团和次级核团. 图 5.1 表明，初级丘脑核可以发挥与较低皮层区域相同的作用，因为它们指向皮层第 IV 层，并接收来自第 VI 层深层锥体细胞的输入（Thomson 2010, Olsen et al. 2012）. 视觉系统中的外侧膝状体就是一个例子，它通常被看成眼与视觉皮层之间的中继站. 与表示预测误差的神经元类似，它既接收来自眼的感觉信息，又接收来自皮层的反馈投射；后者可理解为预测. 次级丘脑核包括背内侧核和丘脑枕，分别与额叶皮层和后部皮层相互作用. 它们可能在预测感觉输入或高阶输入的二阶统计量，即精度与方差，方面发挥作用，并已被联系到图形—背景区分任务（Kanai et al. 2015）. 简单地说，这提示丘脑划分为初级和次级核团，可能体现了一阶与二阶统计量之间的区分.

5.5 神经调质作用与学习

结构神经解剖学很重要，但它只呈现了神经处理的一部分图景，因为连接的存在并不能充分说明连接的使用方式. 以图 5.4 所示黑质的作用为例. 黑质对纹状体连接性的调节效应，使基底神经节产生的输出随多巴胺释放量而大不相同. 这种形式的突触效能快速调节，可以与学习时发生的较慢但更持久的变化相对照. 本节关注突触效能变化的这两种方式.

精度是理解*神经调质作用*（neuromodulation）的重要概念（Feldman and Friston 2010）. 第 4 章及上文关于感觉衰减的讨论已涉及这一点；我们看到，精度作为乘性权重作用于预测误差. 更一般地，精度是对一个概率分布的置信程度的度量. 二者的关系很简单：如果我们对隐状态如何生成数据持有非常精确的信念，那么与缺乏这类信心的情形相比，观测数据就可以使我们对隐状态的信念得到更大程度的更新. 当信念更新表现为神经元放电的变化时，更精确的似然分布就表现为对给定感觉刺激更强的神经响应. 这对于从注意（Parr and Friston 2019a）到多感觉整合（Limanowski and Friston 2019）的认知功能都至关重要.

这种关于突触增益控制的观点告诉我们一件简单而重要的事：如果精度是生成模型中某个分布的属性，那么不同的分布就应当对应不同的精度. 这在直觉上是合理的，因为我们对感觉的可靠性、事物如何随时间演化，甚至自己可能如何行动，都可以具有不

同程度的信心（Parr and Friston 2017b）. 最后一种情形已在基底神经节多巴胺信号传递的背景下讨论过. 相关精度越高，我们就越确信自己的策略会最小化期望自由能.

如果起源于中脑黑质致密部和腹侧被盖区的多巴胺能系统，其作用之一是传递对“做什么” 的信心，那么其他神经调质系统是否发挥类似作用？表 5.1 概括了将精度与神经调质系统联系起来的证据，并列出有时用来表示这些精度的符号. 具体而言，起源于 Meynert 基底核的胆碱能系统似乎传递某些似然分布的精度. 起源于蓝斑的去甲肾上腺素能系统，似乎在传递随时间转移的精度方面发挥作用. 5-羟色胺能系统的作用尚不那么清楚，但可能与先验偏好的精度有关.

表 5.1: 神经递质在主动推断中的假定作用

神经递质	精度	证据
乙酰胆碱	似然（ζ）	• 丘脑至皮层传入通路上存在突触前受体（Sahin et al. 1992, Lavine et al. 1997）. • 调节视觉诱发响应的增益（Gil et al. 1997, Disney et al. 2007）. • 药理操控引起有效连接性的变化（Moran et al. 2013）. • 对药理操控下的行为响应进行建模（Vossel et al. 2014, Marshall et al. 2016）.
去甲肾上腺素	转移（ω）	• 维持前额叶的持续性活动，即延迟期活动，需要精确的转移概率，并依赖去甲肾上腺素（Arnsten and Li 2005, Zhang et al. 2013）. • 对出乎意料，即不精确，的序列产生瞳孔响应（Nassar et al. 2012, Lavín et al. 2013, Liao et al. 2016, Krishnamurthy et al. 2017, Vincent et al. 2019）. • 对药理操控下的行为响应进行建模（Marshall et al. 2016）.
多巴胺	策略（γ）	• 在纹状体中型棘状神经元的突触后部位表达（Freund et al. 1984, Yager et al. 2015）. • 计算功能磁共振成像(fMRI)揭示,精度变化时出现中脑活动（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）. • 对药理操控下的行为响应进行建模（Marshall et al. 2016）.

续下页

表 5.1（续）

神经递质	精度	证据
5-羟色胺	偏好或内感受似然（χ）	• 内侧前额叶皮层第 V 层锥体细胞上表达受体（Aghajanian and Marek 1999, Lambe et al. 2000, Elliott et al. 2018）. • 内侧前额叶皮层区域与内感受处理及自主神经调节密切相关（Marek et al. 2013, Mukherjee et al. 2016）.

来源：Parr and Friston 2018.

为什么能把这些精度与神经调质系统联系起来会很有用？原因有三：它使我们能够解释已观测到的生物学现象、提出假设，并发展非侵入性的精度测量方法. 下面分别举一个例子. 首先，在解释已观测到的生物学现象方面，一个著名发现是，多巴胺信号的实测结果看起来像“奖赏预测误差”（Schultz 1997）：动物在收到意料之外的果汁，或看到预示即将得到果汁的线索时，多巴胺水平会上升. 主动推断为这些发现提供了另一种解释（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）. 得到奖赏，或实现偏好，或者遇到预示未来奖赏的线索，都会增强我们的信心，使我们更加相信自己正在执行能最小化期望自由能的策略. 这种信心的增强表现为多巴胺的瞬时峰值.

其次，在提出假设方面，一个例子涉及路易体痴呆中胆碱能信号传递的减少（Parr, Benrimoh et al. 2018）；这种疾病会导致复杂视幻觉. 对此，一种合理的解释是：较高视觉皮层中病理改变的累积，促使这些区域发出的预测与初级视觉皮层的活动之间出现不匹配. 这种不匹配降低了对相应似然分布的信心，并引起胆碱能信号传递的丧失. 精度丧失的后果是，无法根据感觉数据更新信念，这意味着知觉失去感觉所提供的约束. 这可能解释了该疾病中幻觉性知觉的形成.

第三，在精度参数的非侵入性测量方面，一个例子是计算表型的识别. 中枢神经化学活动有多种外周表现，包括自发眨眼率与多巴胺之间的关系（Karson 1983），以及瞳孔大小与去甲肾上腺素之间的关系（Koss 1986）. 最近探索后一关系的研究（Vincent et al. 2019）表明，理想贝叶斯观察者预期会推断出的转移精度，与瞳孔收缩和扩张的动力学存在关联. 这意味着，我们可以通过这类外周测量来探查一个人隐含的生成模型，即经验先验信念.

虽然精度的快速变化很重要，但它是优化有效连接性的一种粗略方式：它使信号增益增加或减少，却不能作出更细致的改变. 如果要改变对信号的解释方式，就需要依靠学习. 第 7 章将详细回到这一点. 不过，基本思想是：我们不仅对世界的状态持有信念，也对决定变量间依赖关系的固定或缓慢变化的参数持有信念（Friston, FitzGerald et al. 2016）. 这些信念的载体，是表示时变变量，例如隐状态或结果，的神经群体之间突触连接的效能. 当观测到一个我们相信由给定状态生成的结果时，就可以更新关于连接这两者的参数的信念，反映出二者未来共同出现的概率增大. 换言之，这两群神经元之间的突触会增强. 其结果就是 Hebb 的著名论断，意译为：“共同放电的细胞会彼此连接.”

图 5.1 的一个重要特点是：无论在预测编码还是边缘消息传递方案中，进入和离开皮层柱的连接都与似然分布有关. 相比之下，转移概率和连续动力学依赖于微环路内部

的连接. 这提示，对动力学的学习应当导致内在连接性的变化，而对观测模型的学习应当改变外在连接性. 利用动态因果建模等技术，可以根据神经成像数据评估有效连接性度量，从而检验这些假设（Tsvetanov et al. 2016, Zhou et al. 2018）. 这凸显了这类过程理论的作用：它们使我们能够超越抽象推论，提出具体且可检验的假设.

5.6 连续与离散层级

最后，需要强调神经层级中从低层级的连续表示到高层级范畴变量的转变. 要点是，我们讨论过的离散与连续消息传递方案，很可能在大脑中共存；因为我们不仅能够与连续变化的感觉受体和效应器相联系，例如肌肉长度或视觉亮度对比度，还能够持有范畴类型的信念，例如辨认一个物体是什么，或一个人是谁. 这也体现在神经生理学中：有些神经元对特定刺激具有选择性，而另一些神经元的活动随刺激强度成比例变化.

一个有趣的观察是，我们与周围世界的接口处在连续域中，这意味着大脑中任何层级的最低层都必须是连续的. 话虽如此，图 5.4 表明，基底神经节中的策略选择可以表述为一个离散过程，在不同备选运动之间作出选择. 这告诉我们，可以把运动看成将离散轨迹组合成目的性行动的过程. 最低层可能处理肌肉长度所需的变化，而下行输入则基于关于应当作出哪一种运动的决策. 从生成模型的视角看，这意味着把关于世界的不同备选离散假设，与这些假设所蕴含的连续动力学联系起来. 第 8 章将从计算角度回到如何把二者结合起来的问题. 在此只需指出：离感觉受体越远，我们往往越容易在神经系统中发现离散化表示. 事实上，神经生理学中经典感受野的存在本身，就可以解释为一种概率表示，即世界处于知觉状态空间中某个特定区域的概率表示；感受野铺满这一状态空间，从而将其分割为许多小范畴. 图 5.5 把这些方案结合起来，概括了本章提出的思想.

5.7 小结

本章力图概述第 4 章生成模型所蕴含的消息传递方案，与推断、行动及规划的神经生物学之间的联系. 将消息传递与神经元通信联系起来，能带来什么？它使我们能够基于我们假定大脑正在反演的生成模型，作出经验预测. 这种预测可以表现为诱发响应，即给大脑呈现感觉刺激时，在头皮上可以测得的电位变化；其时间过程取决于该刺激引起的信念更新量. 另一种方式是，利用计算神经成像方法，将模拟的推断与表现出相似时间动力学的脑区联系起来（Schwartenbeck, FitzGerald, Mathys, Dolan, and Friston 2015）. 建立这种关联，对于理解计算性障碍，即神经和精神障碍，的病理及治疗很重要，因为它使我们能够用生物学来表述功能病理.

最后，需要承认，本章明显没有涉及大脑的许多部分；这部分是篇幅所限，也因为神经科学仍在发展中. 对本章叙述进行扩展，甚至替换，仍有许多机会. 在某种程度上，我们可以根据本章所见作出外推. 例如，杏仁核的某些部分在细胞构筑上等同于基底神经节核团. 这是否意味着存在一类由杏仁核评估的策略？这一结构对于自主神经策略的作用，是否就像基底神经节对于骨骼运动领域策略的作用？其他结构，例如丘脑枕，是否可能对其他类别的策略，例如心理策略，发挥类似作用？对于不同于图 5.1 中六层结构的皮层架构，应当如何理解？小脑和海马结构各自具有独特而模式化的微环路（Wesson

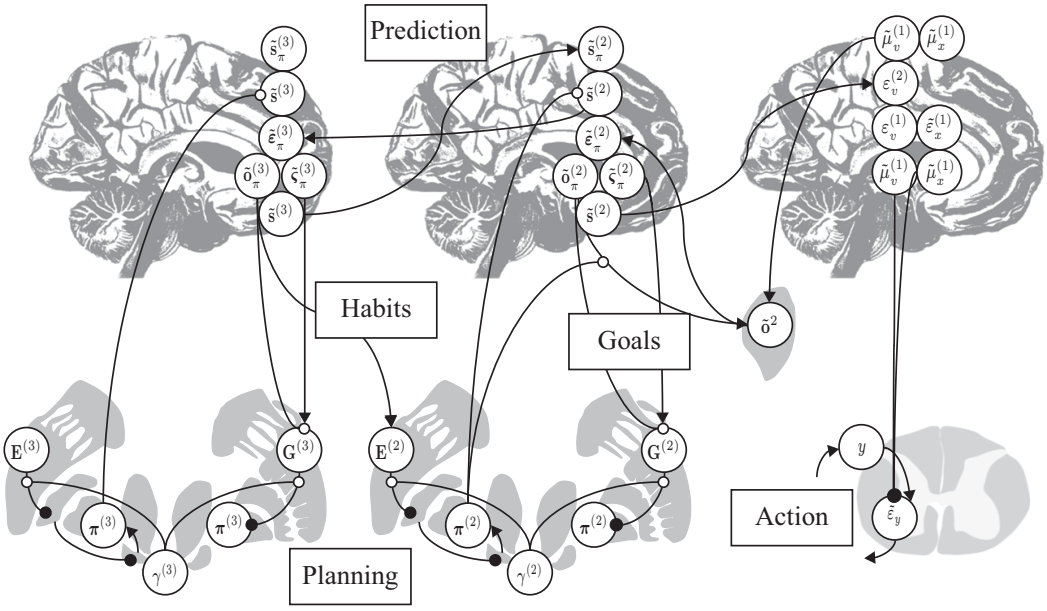


图 5.5: 推断的解剖结构，基于 Friston, Parr, and de Vries 2017，将图 5.1 至图 5.4 的示意图连接起来，概括本章的思想. 两个穿过皮层和基底神经节的层级环路，突出以下区分：一方面是基于较高层级输入的习惯；另一方面是由期望自由能最小化产生、对情境更敏感的目标导向行为，包括探索性和利用性行为. 注意，关于策略的推断会影响 s，从而实现正文所述的策略下贝叶斯模型平均. 这一从基底神经节到皮层的投射，可以经由丘脑等中间结构介导. 右侧，基于范畴 POMDP 的消息被传递到参与行动生成的连续预测编码网络中. 每个范畴状态都与对连续变量的一种备选预测相联系，并对预测误差作出贡献. 反方向的消息计算相关范畴结果 o 的后验概率；该概率依赖于基于策略依赖结果 o_π 的先验、关于策略的信念 π，以及连续轨迹的似然；这一似然可以根据连续层级的后验期望 μ 和方差计算，图中未显示方差. 此处还可以加入更多连接；例如，除习惯 E 外，目标的选择，即第 4 章的 C，本身也很可能依赖较高层级，形成对动机的层级控制，详见 Pezzulo, Rigoli, and Friston 2018. 图中 Prediction 为预测，Habits 为习惯，Goals 为目标，Planning 为规划，Action 为行动.

and Wilson 2011）. 我们应当把它们看成同一套贝叶斯消息传递方案的解剖重排，还是它们处理生成模型的不同方面（Pezzulo, Kemere, and van der Meer 2017；Stoianov et al. 2020）？我们提出这些问题，并非为了给出答案，而是为了突出理论神经生物学未来研究中一些令人兴奋的方向. 主动推断及其相关过程理论，提供了可以据以处理这些问题的严格形式框架和概念框架.

第二部分

Chapter 6

设计主动推断模型的步骤

给我六个小时砍倒一棵树，我会用前四个小时磨斧头.

——Abraham Lincoln

6.1 引言

本章给出构建主动推断模型的四个步骤，讨论实现模型时必须作出的最重要的设计选择，并为这些选择提供一些指导. 本章也是本书第二部分的引言；第二部分将介绍若干使用主动推断的具体计算模型，以及它们在不同认知领域中的应用.

主动推断是一种规范性方法，因此试图从第一性原理出发，尽可能多地解释行为、认知和神经过程. 与此一致，主动推断的设计理念是自上而下的. 与计算神经科学中的许多其他方法不同，挑战在于找到一个生成模型，描述大脑试图解决的问题，而不是逐个部件地仿效大脑. 一旦用生成模型恰当地形式化了问题，主动推断下的问题解答便会随之产生，同时带来关于大脑和心智的预测. 换言之，生成模型给出了对所研究系统的完整描述. 通过最小化自由能，可以从模型导出相应的行为、推断和神经动力学.

许多学科都使用生成建模方法来实现认知模型、统计建模、实验数据分析和机器学习（Hinton 2007b；Lee and Wagenmakers 2014；Pezzulo, Rigoli, and Friston 2015；Allen et al. 2019；Foster 2019）. 这里，我们主要关注如何设计生成模型，使其产生所研究的认知过程. 前几章已展示了这一设计方法. 例如，使用预测编码的生成模型时，知觉被表述为对感觉最可能的原因的推断；使用在离散时间中演化的生成模型时，规划被表述为对最可能的行动路线的推断. 根据所研究的问题，例如空间导航中的规划或视觉搜索中的眼跳规划，可以调整这些生成模型的形式，赋予它们不同的结构，例如浅层或层级结构，以及不同的变量，例如关于以环境为中心或以自我为中心的空间位置的信念. 重要的是，对所优化的生成模型形式作出不同假设，会使主动推断呈现出许多不同面貌. 例如，关于模型在离散时间或连续时间中演化的假设，会影响消息传递的形式，见第 4 章. 这意味着，选择一个生成模型，就对应着关于行为和神经生物学的特定预测.

这种灵活性很有用，因为它使我们能用同一种语言描述多个领域中的过程. 不过，从实践角度看，它也可能造成困惑，因为必须作出若干选择，才能为所研究的系统找到适当的描述层次. 本书第二部分将尝试通过一系列计算机模拟中的主动推断示例，消除这种困惑. 本章介绍设计主动推断模型的一般步骤，突出后续章节计算模型的数值分析中将出现的一些关键设计选择、区分和二分关系.

6.2 设计主动推断模型：四个步骤

设计主动推断模型需要四个基础步骤，每一步都解决一个特定的设计问题：

1. 我们对什么系统建模？首先总要选择所研究的系统. 这未必像看上去那么简单，因为它取决于对系统边界，即马尔可夫毯的识别. 哪些属于主动推断智能体，即生成模型；哪些属于外部环境，即生成过程；二者之间的接口，即感觉数据与行动，是什么？

2. 生成模型最适合采用什么形式？接下来的三个实践挑战中，第一个是判断：更适合从范畴，即离散推断的角度，还是从连续推断的角度思考一个过程，从而选择主动推断的离散时间实现、连续时间实现或混合实现. 然后，需要选择最适当的层级深度，从而选择浅层模型或深层模型. 最后，需要考虑是否有必要赋予生成模型时间深度，以及预测依赖于行动的观测的能力，以支持规划.

3. 如何设置生成模型？生成模型最适当的变量与先验是什么？哪些部分固定，哪些必须学习？我们强调选择合适的变量和先验信念的重要性；此外，还强调推断期间状态变量的较快更新，与学习期间模型参数的较慢更新之间的时间尺度分离.

4. 如何设置生成过程？生成过程由哪些要素组成？这些要素与生成模型有何不同？

在大多数情况下，这四个步骤足以设计一个主动推断模型. 完成之后，系统行为就由主动推断的标准方案决定：主动状态和内部状态沿与模型相关的自由能泛函下降. 从更实际的角度说，一旦指定了生成模型和生成过程，就可以使用标准的主动推断软件例程获得数值结果，并进行数据可视化、分析和拟合，例如基于模型的数据分析. 下面将依次考察这四项设计选择.

6.3 我们对什么系统建模？

应用主动推断形式体系时，一个有用的起点是识别所研究系统的边界，因为我们希望刻画系统内部与外部世界通过感觉受体和效应器，例如肌肉或腺体，进行的相互作用. 如第 3 章所讨论的，可以用马尔可夫毯这一形式工具，刻画系统内部状态、外部变量以及介导二者相互作用的中间变量之间的区别（Pearl 1988）. 重述这一论点，马尔可夫毯可细分为两类变量（Friston 2013）：一类介导外部世界对所研究系统内部状态的影响，即感觉状态；另一类介导所研究系统内部状态对外部世界的影响，即主动状态，见图 6.1.

重要的是，定义内部与外部边界的方式有很多种. 本书第二部分将讨论的大多数模拟，都在智能体，大致而言是一个活的有机体，与环境之间作出马尔可夫毯分隔. 这对应于认知模型的通常设置：智能体基于自身内部状态，例如大脑状态，实现知觉、行动选择等认知过程，并配备传感器和效应器.

不过，这并非唯一的可能性. 从神经生物学的角度看，可以围绕单个神经元、大脑或整个身体划定马尔可夫毯. 第一种情况下，感觉状态包括突触后受体的占有情况，主动状态包括含有神经递质的囊泡与突触前膜融合的速率. 于是，可以把神经元的内部状态，例如膜电位、钙浓度，看作依据某个隐式生成模型，推断其感觉状态的原因（Palacios, Isomura et al. 2019）. 在这一设置中，被建模的外部状态包括该神经元参与的神经网络. 这与假定整个网络处在马尔可夫毯内部时发生的推断很不一样. 例如，若所取系统的感觉状态是视网膜中的光感受器，主动状态是动眼肌，那么内部状态进行的推断就涉

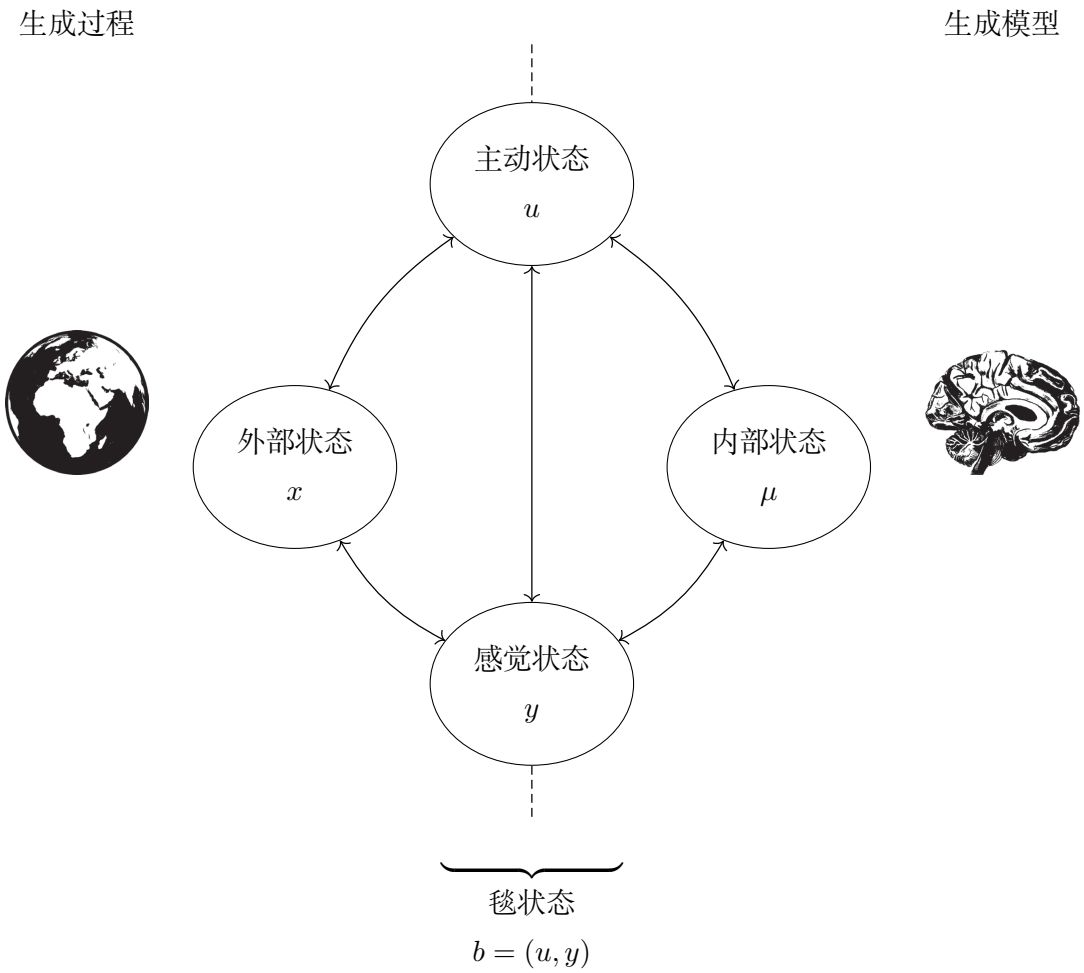


图 6.1: 适应性系统，此处为大脑，与环境之间的行动—知觉环路，以及介导二者相互作用的马尔可夫毯，由主动状态和感觉状态组成. 此图意味着，适应性系统只能通过执行行动，经由主动状态影响环境，而环境只能通过产生观测，经由感觉状态影响适应性系统. 图中说明了适应性系统的生成模型，与产生其观测的外部生成过程之间的区别. (译者绘图说明：节点和箭头以可编辑形式重建，地球与大脑图像提取自原图.)

及大脑以外的事物. 这说明尺度很重要，因为这一马尔可夫毯的内部状态，也包括从单个神经元视角看待的内部状态. 围绕单个神经元划定马尔可夫毯时，后者看起来是在对大脑内部的事物进行推断；围绕神经系统划定马尔可夫毯时，则并非如此.

上述讨论对于具身认知或延展认知的视角尤为相关（Clark and Chalmers 1998; Barsalou 2008; Pezzulo, Lw et al. 2011）. 例如，若围绕神经系统划定马尔可夫毯，身体的其余部分便成为外部状态，需要根据内感受感觉状态对其进行推断（Allen et al. 2019）. 另一种做法是围绕整个有机体划定马尔可夫毯. 这样看来，大脑以外的器官也仿佛在对环境进行推断. 例如，皮肤响应外部压力而产生凹陷，可以表述为对外部压力来源的推断. 延展认知视角更进一步，认为身体以外的物体也可以纳入马尔可夫毯；例如，用计算器辅助推断，意味着计算器属于推断系统内部状态空间的一部分. 最后，还可以有多个彼此嵌套的马尔可夫毯，例如大脑、有机体和群体.

总之，定义马尔可夫毯，能确保我们知道推断的对象是什么，即外部状态，以及进行推断的是什么. 实际上，相对于生成模型最小化自由能，只涉及系统的内部状态与主动状态：它们只能看到感觉状态，因此只能间接推断世界的外部状态.

6.4 生成模型最适合采用什么形式？

确定了系统的内部状态，以及介导内部状态与外部世界相互作用的状态之后，需要指定生成模型，以解释外部状态如何影响感觉状态.

如前几章所讨论的，主动推断可以作用于不同类型的生成模型. 因此，需要针对当前问题，指定最适当的生成模型形式. 这涉及三项主要设计选择. 第一项是在包含连续变量、离散变量或二者兼有的模型之间选择. 第二项是在浅层模型与层级或深层模型之间选择：前者的推断只在单一时间尺度上进行，即所有变量都以同一时间尺度演化；后者的推断在多个时间尺度上进行，即不同变量以不同时间尺度演化. 第三项是在只考虑当前观测的模型，与具有一定时间深度、考虑行动或计划后果的模型之间选择.

6.4.1 离散变量、连续变量，还是二者兼有？

第一项设计选择，是考虑使用离散变量还是连续变量的生成模型更合适. 前者包括物体身份、备选行动计划，以及连续变量的离散化表示. 对它们建模时，要表达每个时间步上一个变量转变为另一类型的概率. 后者包括位置、速度、肌肉长度和亮度等，需要用变化率来表达生成模型.

从计算角度看，二者的区别未必截然分明，因为连续变量可以离散化，而离散变量也可以通过连续变量表达. 不过，这一区别在概念上很重要，因为它构成了关于所研究认知过程的时间进程，即离散还是连续，的特定假设的基础[1]. 在目前主动推断的大多数实现中，高层决策过程，例如在备选行动路线之间作出选择，使用离散变量建模；更精细的知觉与行动动力学，则使用连续变量实现. 第 7、8 章将分别给出这两种情况的例子.

此外，离散变量与连续变量之间的选择，也与神经生物学有关. 两种建模方式都诉诸自由能最小化，但它们蕴含的消息传递具有不同形式. 如果认为消息传递与过程理论相关，见第 5 章，那么这意味着，在每一类模型下，实现这种最小化的神经动力学不同. 连续方案为预测编码提供基础；预测编码是一种神经处理理论，依靠自上而下的预测，

并由自下而上的预测误差加以校正. 然而，离散推断的相应过程理论涉及另一种形式的消息. 最后，两类模型可以结合，使离散状态与连续变量相联系. 这意味着，我们可以指定一个生成模型，其中离散状态，例如物体身份，生成某种连续变量模式，例如亮度模式. 第 8 章将讨论一个同时包含离散变量和连续变量的混合生成模型的例子.

6.4.2 推断的时间尺度：浅层模型与层级模型

第二项设计选择涉及主动推断的时间尺度. 可以选择所有变量都以同一时间尺度演化的浅层生成模型，也可以选择包含在不同时间尺度上演化的变量的层级或深层模型：较高层较慢，较低层较快.

许多简单认知模型只需浅层模型，但如果所研究认知过程的不同方面之间存在明显的时间尺度分离，浅层模型便不够. 语言处理就是一个例子：短的音素序列由正在说出的词提供情境，而短的词序列由当前句子提供情境. 关键在于，词的持续时间超过序列中任何单个音素的持续时间，句子的持续时间又超过序列中任何单个词的持续时间. 因此，对语言处理建模时，可以考虑一个层级模型：句子、词和音素出现在从高到低的不同层级上，并在从慢到快、彼此近似独立的时间尺度上演化. 这种分离只是近似的，因为各层级必须相互影响，例如句子影响序列中的后续词，词影响序列中的后续音素.

不过，这并不意味着，为了对单个层级作有意义的模拟，就需要尝试对整个大脑建模. 例如，若想关注词处理，可以在不处理音素处理过程的情况下研究其中一些方面. 这意味着，从词处理区域的视角看，可以把来自大脑中对音素进行推断的部分的输入，当作观测. 用马尔可夫毯的语言表达，这通常意味着把模型较低层进行的推断视为毯的感觉状态的一部分. 如此便能概括所关注时间尺度上的推断，而无须指定较低层、更快推断过程的细节；这种层级因子分解带来很大的计算收益.

另一个例子来自意向性行动选择：同一个目标，例如进入自己的公寓，可以在较长时间内保持激活，并为一系列子目标和行动，例如找钥匙、开门、进入，提供情境；后者在快得多的时间尺度上完成. 无论在连续域还是离散域，这种时间尺度分离都要求层级或深层生成模型. 在神经科学中，可以假定皮层层级包含这种时间尺度分离：较高层的状态缓慢演化，较低层的状态快速演化；而这复现了同样在多个时间尺度上演化的环境动力学，例如语音识别或阅读等知觉任务中的动力学. 在心理学中，这类模型有助于再现层级目标处理（Pezzulo, Rigoli, and Friston 2018），以及依赖延迟期活动（Funahashi et al. 1989）的工作记忆任务（Parr and Friston 2017c）.

6.4.3 推断与规划的时间深度

第三项设计选择涉及推断的时间深度（temporal depth）. 必须区分两类生成模型：第一类具有时间深度，明确表示行动或行动序列，即策略或计划，的后果；第二类缺乏时间深度，只考虑当前观测，不考虑未来观测. 图 4.3 给出了这两类模型的例子：上方的动态 POMDP，以及下方的连续时间模型[2]. 这两个模型的关键区别，在于只有前一种具有时间深度的模型，才赋予生物体提前规划、在可能的未来之间作出选择的能力，而不在于它们分别使用离散变量或连续变量.

设想一只啮齿动物在迷宫中规划一条通向已知食物位置的路线. 具有时间深度的模型有助于完成这一过程；它大致相当于空间地图或认知地图（Tolman 1948），编码以行

动为条件的当前位置与未来位置之间的依存关系，例如右转或左转之后的未来位置. 动物可以使用具有时间深度的模型，以反事实方式考虑多条行动路线，例如一系列右转和左转，并选择预期能到达食物位置的路线.

为什么规划需要具有时间深度的模型？在主动推断中，规划通过计算不同动作或策略对应的期望自由能，并选择期望自由能最低的策略来实现. 期望自由能不仅像变分自由能那样，是当前观测的函数，也是未来观测的泛函. 按定义，未来观测无法被观测，只能用具有时间深度的模型来预测；该模型描述行动产生未来观测的方式.

设计主动推断智能体时，考虑它是否应当具有规划和面向未来的能力很有用；若应具备这些能力，就要选择具有时间深度的模型. 此外，还应考虑规划深度，即规划过程能够向未来看多远. 最后，可以设计既有层级结构又有时间深度的生成模型，其中规划在多个时间尺度上进行：较低层较快，较高层较慢[3]. 是否要对依赖策略选择的备选未来建模，很大程度上与离散模型和连续模型之间的选择有关，因为使用离散时间模型，更容易表达在由行动序列定义的备选未来之间作出选择这一思想.

6.5 如何设置生成模型？

指定了所研究的系统，并确定生成模型的相关形式，例如连续或离散表示、浅层或层级结构之后，接下来的挑战是指定生成模型要包含哪些具体变量，并决定其中哪些变量保持固定，哪些会因学习而改变.

6.5.1 设置生成模型的变量

生成模型的变量可以预先定义，也可以从数据中学习. 为了便于说明，本书讨论的大多数模型使用预先定义的变量. 在实践中，设计这些模型的主要挑战，是决定哪些隐状态、观测和行动最适合当前问题. 例如，第 2 章中能够区分青蛙与苹果的知觉模型，只包含两个隐状态，即青蛙、苹果，以及两个观测，即跳跃、不跳跃. 更复杂的模型可以包含额外的观测，例如红色、绿色，以及触摸等行动；在青蛙或苹果存在时，这些行动会产生不同的感觉效果，即跳跃或不跳跃.

图 6.2 示意了“跳跃的青蛙”这一概念的生成模型. 该概念被表述为一个层级模型：图中央的单个多模态或超模态隐状态，展开为一连串单模态隐状态，对应不同模态中的知觉，即外感受、本体感受和内感受，见框 6.1，最终产生相同模态中的感觉. 这种安排把跳跃的青蛙这一概念，表述为多个感觉后果的共同原因，例如视觉域中绿色且会跳跃的东西，或听觉域中的呱呱声；其中一些后果可能依赖行动，例如触摸之后，看到某物跳跃的可能性可能增大. 生成模型的反演，对应于从观测到的感觉后果，例如看到某种绿色、会跳跃的东西，推断知觉，例如存在一只跳跃的青蛙，并整合多个模态的信息.

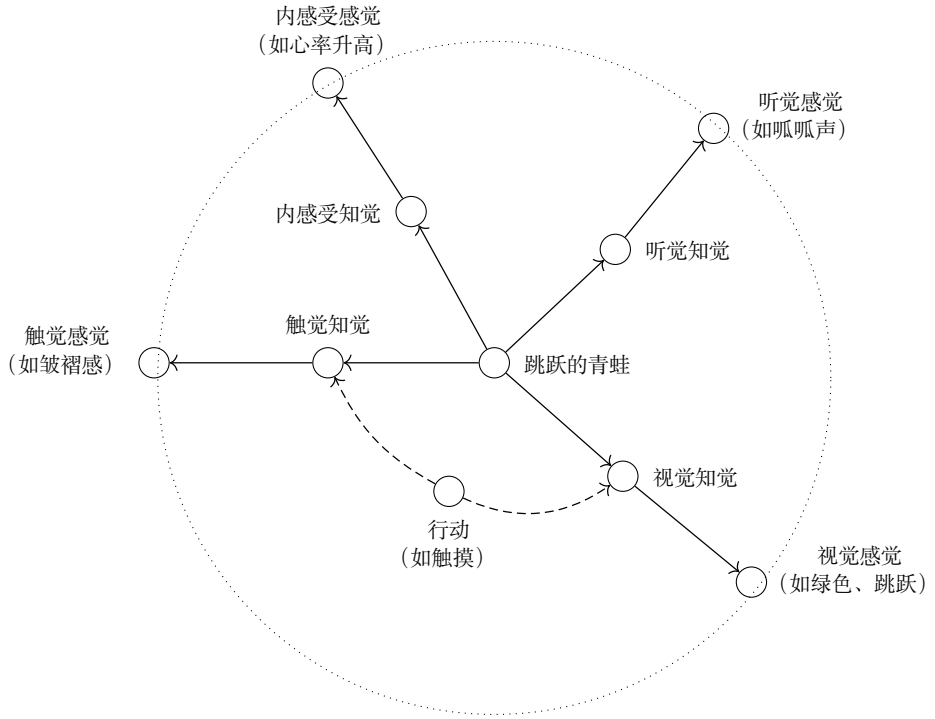


图 6.2: “跳跃的青蛙” 概念的层级生成模型，采用比第 4 章更简化的记号：点线圆内的节点对应隐状态，外围节点对应感觉观测. 模型反演后关于隐状态的信念，对应于知觉；这些知觉可以与某一感觉模态相联系，例如视觉知觉，也可以是非模态的，例如跳跃的青蛙. 依赖行动的关系用虚线表示. 为了简化，省略了不同模态隐状态之间的横向依赖关系，以及隐状态之间的时间依赖关系，后者曾见于第 4 章的动态生成模型.

框 6.1：感觉模态的种类——外感受、本体感受与内感受

主动推断中，常在概念上区分三类感觉模态：外感受，例如视觉和听觉；本体感受，例如对关节和肢体位置的感觉；内感受，例如对心脏、胃等身体内部器官的感觉. 在多模态生成模型中，常可对模型中与不同模态相关的部分作因子分解；这允许表示例如眼跳运动会产生视觉后果，而不会产生听觉后果.

重要的是，相同的主动推断原理作用于所有模态. 例如，视觉处理可以描述为对知觉场景的隐变量的推断；同样，内感受处理可以描述为对表征身体内部状态的隐变量的推断. 此外，改变知觉场景的运动动作，与改变内感受状态的内部指向行动，可以用类似方式描述. 前者调动脊髓反射，以满足本体感受预测；后者调动自主神经反射，以满足内感受预测. 这种内感受处理支持异稳态调节（allostasis）与适应性调节，其功能障碍可能带来精神病理学后果（Pezzulo 2013；Seth 2013；Pezzulo and Levin 2015；Seth and Friston 2016；Allen et al. 2019）.

确定这些所关注的变量后，接下来要写出完整的生成模型. 图 2.1 中青蛙与苹果的简单生成模型就是一个例子；关于隐状态的先验信念，以及隐状态与观测之间的似然映射，完整指定了该模型；数值既可以手动指定，也可以从数据中学习，见第 6.5.2 节.

在这一简单例子以外，需要指定哪些要素，完全由所选生成模型的形式决定. 例如，图 4.3 上方所示的离散时间 POMDP 模型，需要指定 A、B、C、D 和 E 矩阵；连续方案使用类似的要素，虽然没有这么多字母，第 8 章将予以处理. 不过，即使在这些较复杂的情况下，要做的事与上文也没有太大区别：指定关于所关注变量的先验信念，例如在离散时间实现中，D 向量中关于第一时间步隐状态的先验信念，以及 C 矩阵中关于观测的先验信念；并指定它们的概率映射，例如 A 矩阵中隐状态与观测之间的似然映射. 不过，有时考虑生成模型状态空间的因子分解很有用；若某些组合没有必要，就可以避免考虑变量的每一种可能组合. 第 7 章将讨论知觉处理中“什么”与“哪里”通路之间因子分解的一个生物学上合理的例子（Ungerleider and Haxby 1994）：这两条通路分别对应表示物体身份和位置的变量；由于二者通常彼此不随对方变化，可以在模型中独立处理，从而简化模型.

决定关注哪些变量，以及它们在模型中以何种方式关联或作因子分解，往往是模型设计中最具挑战、也最富创造性的部分. 这是把认知假设转化为支持主动推断的数学形式的过程. 我们应当如何选择“正确的”变量？归根结底，这涉及指定合理的备选模型，并选取自由能最低者，参见贝叶斯模型比较. 不过，对大多数研究而言，一个实用的视角是：生成模型应当尽可能接近我们所认为的数据生成方式. 在认知心理学中使用主动推断时，这通常意味着思考实验心理学家会怎样生成呈现给被试的刺激. 将这些过程用所需的概率分布形式化，就得到一个生成模型；其自由能最小化动力学自然会带来相应任务的执行.

这里可以与大多数贝叶斯知觉模型，或理想观察者模型，作类比：模型被设计为在很大程度上模仿当前任务的结构，就像第 2 章辨认青蛙或苹果的例子. 这一思想有时被等同于良好调节器定理（Conant and Ashby 1970）；该定理指出，要有效调节环境，生物体或人工系统必须是该系统的良好模型. 从生态位构建的视角，这有时被表述为生物体模型对其环境的统计适合度，反之亦然（Bruineberg et al. 2018）. 不过，这并不意味着智能体的生成模型必须与实际生成数据的生成过程相同. 对于大多数实际应用，它

可以有所简化或有所不同. 本章稍后的第 6.6 节将回到这一点.

框 6.2：先验与经验行为

选择先验问题的另一种视角，来自一组称为完全类定理的结果（Wald 1947；Daunizeau et al. 2010）. 这些结果指出，在适当的一组先验信念下，任何统计决策程序，即行为，都可以表述为贝叶斯最优. 这意味着，如果我们关心的是解释经验行为，挑战就在于识别能够尽可能简单地再现该行为的生成模型，包括其中的先验信念. 简言之，先验是关于所研究系统的一项假设的陈述. 如果其他先验信念也合理，就有机会通过贝叶斯模型比较，利用经验数据检验这些假设. 这也关系到临床人群的计算表型研究. 总存在一组使行为成为贝叶斯最优的先验信念，这意味着，在理解导致精神或神经综合征的计算缺陷时，关键问题是这些先验究竟是什么. 这一思想初看有些违反直觉. 不过，完全类定理意味着，询问一种行为是否为贝叶斯最优是没有意义的. 重要的问题是：什么样的先验信念会使其最优？第 9 章将展示，诉诸基于我们作为科学家自身信念的自由能最小化，如何提供回答这一问题的方法.[a]

[a]译注：本框保留作者对完全类定理的概括. 本章没有列出所用定理的具体版本、容许性以及先验和决策类等成立条件，也未给出任意行为均可被精确表述为贝叶斯最优的独立证明；不宜把这一概括直接用作无条件的普遍定理.

6.5.2 生成模型的哪些部分固定，哪些通过学习得到？

另一项设计选择，是决定生成模型的哪些部分固定，哪些会因学习而随时间更新. 原则上，主动推断允许模型的每个部分，甚至模型结构，都随时间更新或学习. 因此，学习是一项设计选择，并非必需. 与此一致，我们将介绍完全手工设计的主动推断模型，也会介绍其中某些部分，例如转移概率，保持固定，而其他部分，例如似然，随时间更新的模型.

在主动推断中，学习被表述为推断的一个方面，是最小化自由能的过程. 到目前为止，我们把推断描述为关于生成模型状态的信念更新. 十分类似地，可以把学习描述为关于生成模型参数的信念更新. 为此，生成模型必须具有关于待学习分布的参数的先验信念；具体参数取决于每个变量对应的概率分布，例如高斯分布的均值和方差. 每当遇到新数据，这些先验值就会更新，形成后验信念. 如第 7 章将讨论的，这种更新的算法形式，与状态变量的更新相同.

推断与学习都使用同一种贝叶斯信念更新，这在设计模型时可能显得令人困惑，部分原因是，决定什么应建模为状态、什么应建模为参数，并不总是直接明了的. 不过，对于认知模型，推断与学习有一个明确区别. 推断描述关于模型状态的信念的快速变化，例如在观察到某种红色东西之后，如何更新面前有一个苹果的信念. 学习描述关于模型参数的信念的缓慢变化，例如在多次观察到红苹果之后，如何更新似然分布，提高苹果—红色映射的值. 关于参数的信念，通常比关于状态的信念变化慢得多，而且可能只有在完成状态推断之后才更新. 从神经生物学的角度看，把推断对应到神经元动力学、把学习对应到突触可塑性，是很有吸引力的. 此外，如第 7 章将讨论的，对模型参数持有概率信念，会引发寻求新奇的行为，使生物体可以选择最佳数据，来学习其世界的因果结构. 这提示，赋予主动推断模型学习参数，甚至学习结构，的能力，见第 7 章，是研

究主动学习和基于好奇心的探索之行为动力学的有效方式.

本节结束前，需要指出，本书示例中的生成模型相当简单，使用表格方法定义，例如显式的先验矩阵和似然矩阵，并在小状态空间中运行. 相比之下，机器学习、深度学习和机器人学等领域，正在开发复杂得多的生成模型及相应学习方案，例如变分自编码器（Kingma and Welling 2014）、生成对抗网络（Goodfellow et al. 2014）、递归皮层网络（George et al. 2017）以及世界模型（Ha and Schmidhuber 2018）. 原则上，可以借用这些方法，以及许多其他方法中的任一种，实现主动推断模型的一个或多个部分，例如似然模型或转移模型. 借助最新的机器学习方法，可以把主动推断扩展到越来越具有挑战性的领域与应用；例如见 Ueltzhöffer 2018 和 Millidge 2019.

不过，设计使用复杂机器学习模型的主动推断模型时，有一些重要问题需要考虑，尤其是当我们关心认知和神经生物学含义时. 主动推断的吸引力之一，在于它假定知觉推断、行动规划和学习等，都源自同一自由能最小化过程，从而提供了关于认知功能的整合视角. 例如，如果把彼此独立运行或学习的生成模型并置起来，这种整合能力就会丧失. 此外，上述机器学习方法对应的过程模型不同于主动推断，具有不同的认知和神经生物学解释. 最后，使用机器学习方法时，这里讨论的某些设计选择，例如模型变量的选择，可以略去，因为它们是学习涌现的性质；但它们可能被其他设计选择取代，例如深度神经网络的层数、参数与学习率. 这些设计选择可能具有相关的认知和神经生物学含义，但超出了这里讨论的范围.

6.6 设置生成过程

在主动推断中，生成过程描述主动推断智能体以外世界的动力学，也就是决定智能体观测的过程，见图 6.1. 在描述智能体的生成模型之后，才定义生成过程，这似乎有些奇怪. 毕竟，建模者一开始心里就会有某个任务和生成过程，因此，颠倒顺序、先设计生成过程再设计生成模型，完全合理；尤其是在生成模型必须通过情境化交互来学习的应用中，例如游戏或机器人情境（Ueltzhöffer 2018；Millidge 2019；Sancaktar et al. 2020）.

我们推迟设计生成过程，是因为在本书讨论的许多实际应用中，直接假定生成过程的动力学与生成模型相同，或非常相近. 换言之，通常假定智能体的生成模型紧密模仿产生其观测的过程. 这并不等于说智能体完全了解环境. 实际上，即使智能体知道产生其观测的过程，也可能不确定例如自己在这一过程中的初始状态，就像苹果与青蛙的例子. 用离散时间主动推断的语言说，可以设计这样一个模型：生成模型和生成过程都由同一个 A 矩阵刻画，但智能体对自身初始状态的信念，即属于生成模型的 D 向量，与生成过程的真实初始状态不同，甚至不一致. 需要注意的一个细微之处是，即使生成模型和生成过程都由相同的 A、B 矩阵刻画，它们的语义也不同. 生成过程的 A 矩阵是环境的客观性质，在贝叶斯模型中有时称为测量分布；生成模型的 A 矩阵则编码智能体的主观信念，在贝叶斯模型中称为似然函数.

当然，除了最简单的情况以外，并不要求生成模型与生成过程相同. 在主动推断的实际实现中，总可以把生成过程与生成模型分开指定，既可以使用不同于生成模型的方程，也可以使用其他方法，例如以行动为输入、以观测为输出的游戏模拟器（Cullen et al. 2018），从而遵循图 6.1 中马尔可夫毯蕴含的通常的行动—知觉环路.

设计与生成过程相似或不相似的生成模型，具有一些哲学含义（Hohwy 2013；Clark 2015；Pezzulo, Donnarumma et al. 2017；Nave et al. 2020；Tschantz et al. 2020）. 如上文所述，良好调节器定理（Conant and Ashby 1970）指出，有效的适应性生物体，必须拥有或本身成为它所调节系统的良好模型. 不过，这可以通过多种方式实现. 第一，如此前讨论的，生物体的生成模型可以至少在很大程度上模仿生成过程. 由于内部状态与环境外部状态之间的相似性，这样建立的模型可以称为显式模型或环境模型. 第二，只要能够正确处理环境中那些有助于适应性行动和实现目标的方面，生物体的生成模型就可以比生成过程简约得多，甚至与之明显不同. 这样建立的模型可以称为感觉运动模型或行动导向模型，因为它们主要编码行动—观测关系，或感觉运动依存关系，首要作用是支持目标导向行动，而不是准确描述环境.

考虑如何对一只试图逃出迷宫的啮齿动物建模，迷宫中有些走廊是死胡同，就能理解显式模型与行动导向模型的区别. 显式生成模型可以类似于迷宫的认知地图，详细刻画特定位置、走廊和死胡同等外部实体. 该模型可以使啮齿动物通过基于地图的导航逃出迷宫. 行动导向模型则可以编码胡须运动与触觉感觉之间的依存关系. 后一种模型允许选择适合情境的策略，例如没有体验到或预期到触觉感觉时向前移动，反之则改变方向；最终，即使不显式表示位置、走廊或死胡同，也能使啮齿动物逃出迷宫. 这两类模型引出了对主动推断的不同哲学解释：把生成模型看作重建外部环境的方式，即显式模型，或实现准确行动控制的方式，即行动导向模型.

最后，如形态计算（morphological computation）领域所讨论的（Pfeifer and Bongard 2006），生物体或机器人的某些控制功能，可以交由身体承担，因此无须编码在生成模型中. 被动动力学行走器就是一个例子：这是一种类似人体的物理物体，由两条“腿”和两条“臂”组成，无须传感器、电机或控制器，就能沿斜坡行走（Collins et al. 2016）. 这意味着，至少某些运动或其他能力，可以通过精心调谐、能够利用环境依存关系的身体力学来实现，例如适当的体重或尺寸使其行走而不滑倒；因此，这些依存关系无须编码在生物体的生成模型中. 这提示了另一种设计主动推断智能体及其身体的方式：它们本身就是环境的良好模型，而不仅仅是拥有这样的模型. 不过，设计主动推断模型的各种方式并非互相排斥，而可以根据所研究的问题恰当地结合.

6.7 使用主动推断进行模拟、可视化、分析与数据拟合

在大多数实际应用中，一旦定义了生成模型与生成过程，就只需使用主动推断的标准程序，即主动状态和内部状态沿与模型相关的自由能泛函下降，便能获得数值结果. 可以说，建模者的目标是模拟、可视化、分析与拟合数据，例如开展基于模型的数据分析. 支持所有这些功能的标准主动推断例程，可以免费获取：https://www.fil.ion.ucl.ac.uk/spm/；附录 C 给出了使用这些例程的带注释示例.

虽然在大多数情况下，主动推断程序可以直接使用，但在某些实际应用中，可以考虑特定的微调或改动. 例如，指定规划的时间深度，就定义了计算期望自由能时考虑多少个未来状态. 设定有限的时间深度，并结合采样等其他穷举搜索的近似方法（Fountas et al. 2020），可能有助于在大状态空间中实际应用主动推断.

调整主动推断标准运行方式的另一个例子，是有选择地移除期望自由能方程的部分项. 这种消融有助于比较使用期望自由能的标准主动推断，与抑制了期望自由能某些部

分的简化版本；这些简化版本在形式上类似于例如 KL 控制或效用最大化系统（Friston, Rigoli et al. 2015）. 此外，还可以给主动推断模型增加额外机制，例如习惯学习（Friston, FitzGerald et al. 2016）或学习率调节（Sales et al. 2019）；但有一点限制：要保持主动推断的规范性，就必须用自由能最小化来表述这些额外机制.

最后，对主动推断的其他微调或改动，可能有助于刻画推断障碍和精神病理状态；例如，通过过高或过低的神经调质水平，赋予生物体生成模型过强或过弱的先验，探索其行为与神经元后果. 第 9 章将给出一些与精神病理学有关的主动推断模型示例.

6.8 小结

本章概述了建立主动推断模型时必须作出的最重要的设计选择. 我们给出了四个步骤，以及处理模型设计者通常面临的挑战的一些指导. 当然，无须僵硬地遵循这些步骤. 有些步骤可以颠倒，例如先设计生成过程，再设计生成模型，也可以合并. 不过，一般而言，这些步骤都是必需的. 这为本书余下内容奠定了基础；后续将通过一系列说明性示例，把这些思想付诸实践，展示本书前半部分提出的理论原理. 以下所有例子之间的区别，都只在于这里强调的设计选择. 第二部分展示具有不同边界、在不同时间尺度上具有离散或连续动力学的系统；对这些系统而言，先验信念的选择，是再现许多不同领域行为的关键，但它们都实现了同一种主动推断.

Chapter 7

离散时间中的主动推断

不能创造的东西，我就不理解.
——Richard Feynman

7.1 引言

此前，我们在相对抽象的层面讨论了主动推断的原理. 本章讨论具体例子，以及如何在实际情境中指定它们. 我们关注离散时间中范畴变量的模型. 通过一系列复杂性逐步增加的例子，展示知觉加工、决策、信息寻求、学习和层级推断的模型. 选择这些例子，是为了尽可能简单地突出主动推断方案的涌现性质，包括可测量的生理活动与行为.

7.2 知觉加工

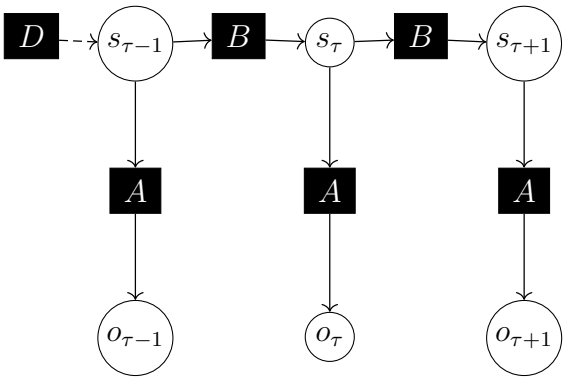
首先考虑知觉加工，以及第 4 章介绍的那类离散时间模型的反演. 本章稍后将逐步构建完整的部分可观测马尔可夫决策过程（POMDP）. 不过，我们从可以忽略选择和行为的 POMDP 特例开始：隐马尔可夫模型（hidden Markov model，HMM）；它可用于序列性的范畴知觉推断，见图 7.1. 用一个简单例子说明动机. 想象自己在听一小段音乐演奏. 乐谱上写出的音符序列可视为隐藏的、未被观测的状态，而实际听到的音符序列则是可观测的结果. 如果演奏者是专业音乐家，隐状态与结果的对应可能十分紧密. 但如果是业余演奏者，从应当演奏的音符到实际听到的音符之间的似然映射，就可能多一些随机性. 在这种情况下，给定关于每个音符之前或之后出现另一个音符的概率的先验信念，仍可能推断出本应听到哪个音符.

听业余音乐家演奏的例子可形式化如下. 首先，决定音乐家实际奏出的音符，即结果，多可靠地符合她想演奏的音符，即隐状态. 这可以用 A 矩阵表达，其元素表示给定某个状态（列）时某个结果（行）的概率. 在这个玩具例子中，设

$$\mathbf{A} = \frac{1}{10}\begin{bmatrix} 7 & 1 & 1 & 1 \\ 1 & 7 & 1 & 1 \\ 1 & 1 & 7 & 1 \\ 1 & 1 & 1 & 7 \end{bmatrix}. \tag{7.1}$$

这表示音乐家有 70% 的时间奏对她想演奏的音符. 接着用 B 矩阵指定转移概率，即给定当前状态（列）时下一个状态（行）的概率：

$$\mathbf{B} = \frac{1}{100}\begin{bmatrix} 1 & 1 & 1 & 97 \\ 97 & 1 & 1 & 1 \\ 1 & 97 & 1 & 1 \\ 1 & 1 & 97 & 1 \end{bmatrix}. \tag{7.2}$$



$$D:\ P(s_1), \qquad A:\ P(o_\tau \mid s_\tau), \qquad B:\ P(s_{\tau+1} \mid s_\tau).$$

图 7.1: 隐马尔可夫模型沿用第 4 章的记号，表达随时间演化的状态 s 序列. 每个时刻的状态产生一个可观测结果 o. 某时刻的状态只依赖前一时刻的状态，这种依赖由 B 表达. 序列首状态的先验概率为 D. 从状态生成结果取决于似然分布 A. 这是 HMM 的一般指定，具体生成模型取决于对 A、B、D 的具体选择.

这表示第一个音符之后接第二个音符、第二个之后接第三个，依此类推，其概率为 97%. 如果知道序列始终从第一个音符开始，就设置先验概率

$$\mathbf{D} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}. \tag{7.3}$$

式 (7.1)–(7.3) 共同完整指定了图 7.1 中的 HMM 生成模型. 换言之，它们描述了我们关于所听音乐如何由这位业余音乐家生成的信念. 使用式 (4.12) 并代入此生成模型[6]，就能模拟结果序列所诱发的贝叶斯信念更新动力学，见图 7.2. 注意左上图中，随着数据逐渐积累，置信度提高；第三个时间步例外，因为此时出现了意外结果. 这有两种解释. 第一，实际想演奏的音符，在式 (7.2) 的先验信念下确实是一个不寻常的音符. 但模型的 B 矩阵中这种转移十分罕见，因此这一解释较不可能. 另一种更合理的解释，是音乐家不小心弹错了音符. 右上图第三列表明，模拟听者最终采用了后一解释. 但他也给 “毕竟弹对了” 的可能性赋予非零概率. 能表达这类不确定性，是主动推断所提供的贝叶斯视角的一项关键特征.

这里的模型可以通过许多方式变得更复杂，但也许最简单的一种是对状态空间作因子分解（Mirza et al. 2016）. 例如分解为音符的音高与力度，结果中也作相应区分. 在视觉推断任务中，可以分解为 “是什么” 和 “在哪里”，这种区分在神经生物学中很常见（Ungerleider and Haxby 1994）. 后续各节将用这类分解，把相关生物能够影响的状态与无法影响的状态分开. 关于这类不包含行动的模型，以及通过最小化自由能来反演它们时可能采用的神经元消息传递方案，进一步阅读见 Parr, Markovic et al.（2019）.

[6]译注：源文指式（4.12），即平均场分解；具体信念更新动力学在其后，见式 (4.13). 此处保留原指向并说明其范围.

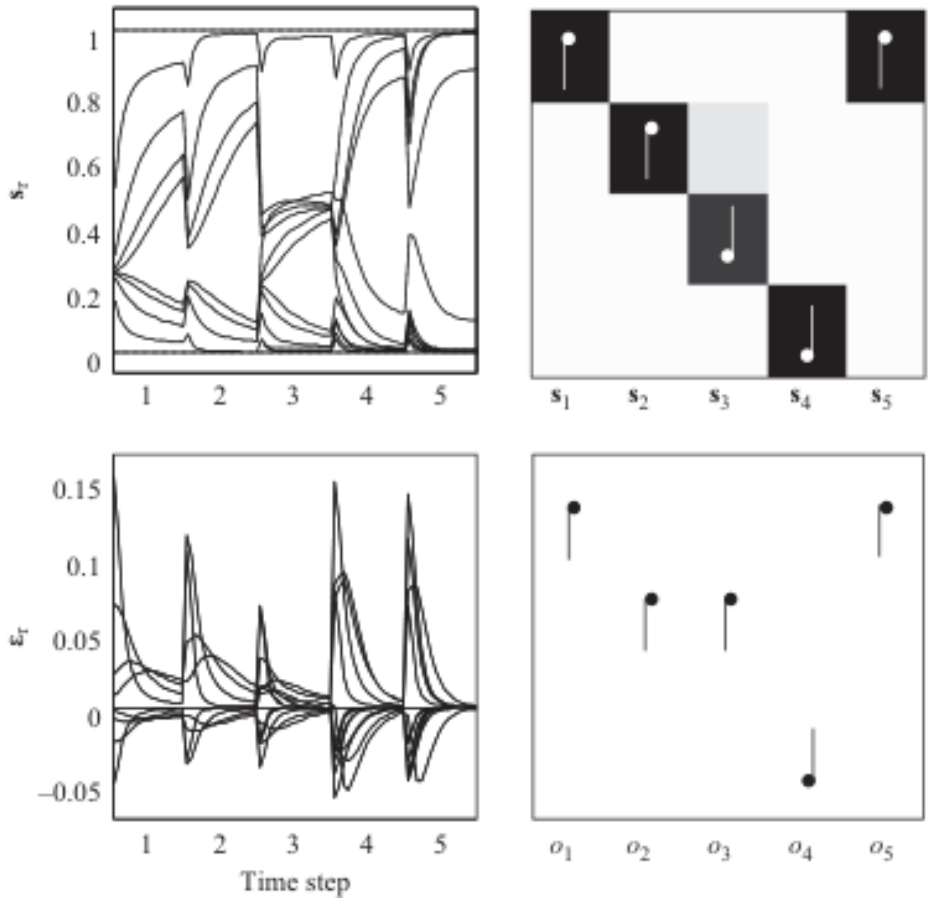
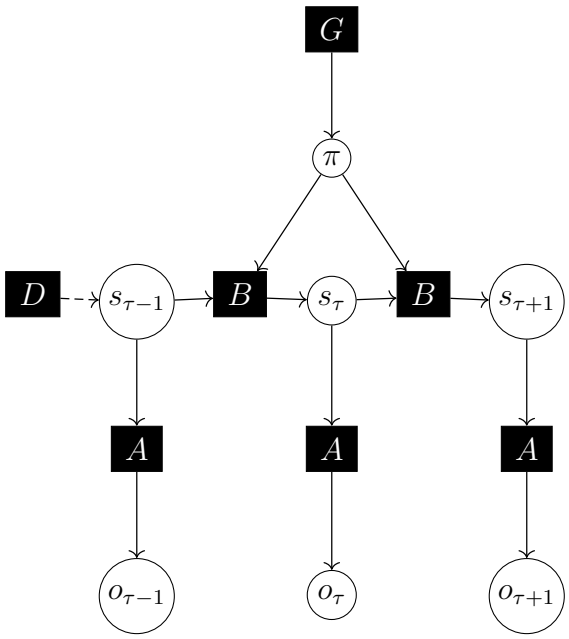


图 7.2: 模拟知觉推断图展示基于正文生成模型的一次示例试验中的信念更新过程. 左上：每个时间步关于序列中各音符的信念，即后验概率. 右上：由于这些信念的数值难以追踪，给出听完每个音符后、序列结束时的信念，即回溯信念. 每列表示给定时间步隐状态的回溯信念，每行表示该隐状态的一种备选假设. 阴影越深，认为那个音符出现过的概率越高；黑色表示概率为一，白色表示零. 左下：随时间变化的负自由能梯度，即预测误差. 左上图信念的变化率由各时间步的这些误差值决定. 右下：呈现给合成智能体的音符序列，即时间步 1 至 5 所接收的观测. 注意第三步 o_3 听到的是第二个音符，见右下图第三列，但听者以更高概率推断为第三个音符，见右上图第三列. 图内 Time step：时间步.

7.3 作为推断的决策与规划

上面的 HMM 展示了基于结果序列的一种十分简单的范畴推断. 不过，它所描述的那种固着不动的生物未免乏味. 自主生物显然不仅是感觉数据的被动接收者；它们主动改变环境，与自己的感觉世界进行双向交流. 因而需要把 HMM 转变为 POMDP：既要推断环境如何变化，也要推断所选行动路线如何改变环境，以及应当选择哪条路线.

图 7.3 是 POMDP 生成模型. 它与第 4 章介绍、并展开其推断细节的模型相同. 注意其结构与图 7.1 的 HMM 相似，只增加了一个变量 π，转移概率 B 以它为条件. 这意味着可以考虑关于状态动力学的备选假设；可将这些假设解释为生物可以从中选择的计划. 这一视角把策略评估等同于模型比较，并认为策略只是对观测到的、由自身产生的感觉序列的一项解释变量.



$A:\ P(o^m_\tau \mid s^1_\tau, s^2_\tau, \ldots, s^n_\tau, \ldots)$, $\quad B:\ P(s^n_{\tau+1} \mid s^n_\tau, \pi)$,

$C:\ P(o^m_\tau)$, $\quad D:\ P(s^n_1)$, $\quad G:\ P(\pi \mid C, E)$.

图 7.3: 原书图 4.3 的 POMDP，用隐状态因子和结果模态展开各概率分布；图 7.1 是其特例. 三点值得注意. 第一，隐状态的因子分解意味着 A 编码的分布在条件集中可能有许多状态因子，因而不能再用矩阵编码，而成为各索引分别对应一个状态因子的张量. 第二，把结果分成不同模态意味着，每种模态都对应一个单独的 A 张量. 第三，C、E 虽列于右侧概率说明中，却不直接出现在左侧因子图，因为它们只通过关于策略的先验信念进入生成模型. 另一种视角见 Parr and Friston（2018d）及 van de Laar and de Vries（2019）.

此模型与第 4 章模型的细微差别，是允许把状态（上标 n）和结果（上标 m）分别因子分解. 想想把视觉世界分成物体在哪里以及它是什么，就能看出其用途. 物体身份通常不随位置变化，反之亦然；若仍表示位置与身份的每一种组合，显然极低效，并会产生高复杂度代价. 类似论证也可用于把时间与身份、位置因子分解（Friston and

Buzsaki 2016）. 此时引入这种分解的好处，是可以分开生物能够控制和不能控制的世界状态. 前者的转移概率随策略而变，后者则不随策略变化.

有了这些准备，现概述一个需要规划的简单任务（Friston, FitzGerald et al. 2017），展示使用 POMDP 的主动推断的一些关键方面. 一只大鼠处在 T 形迷宫中：一个臂有厌恶刺激，另一个有吸引刺激，最后一个臂有指示两种刺激位置的线索. 这种设置意味着，大鼠大体上可以采取两类行为. 它可以冒着遇到厌恶刺激的风险，直接走向可能含有吸引刺激的两个臂之一；也可以先寻找信息性线索，再走向最可能含有吸引刺激的臂.

这一选择涉及心理学中经典的探索—利用困境；主动推断解决了这一困境. 解决方法来自策略先验信念所要求的期望自由能最小化. 简要回顾如下，细节见第 4 章：对最小化变分自由能的生物而言，最可能的策略是导致最低期望自由能的策略. 期望自由能具有如下形式：

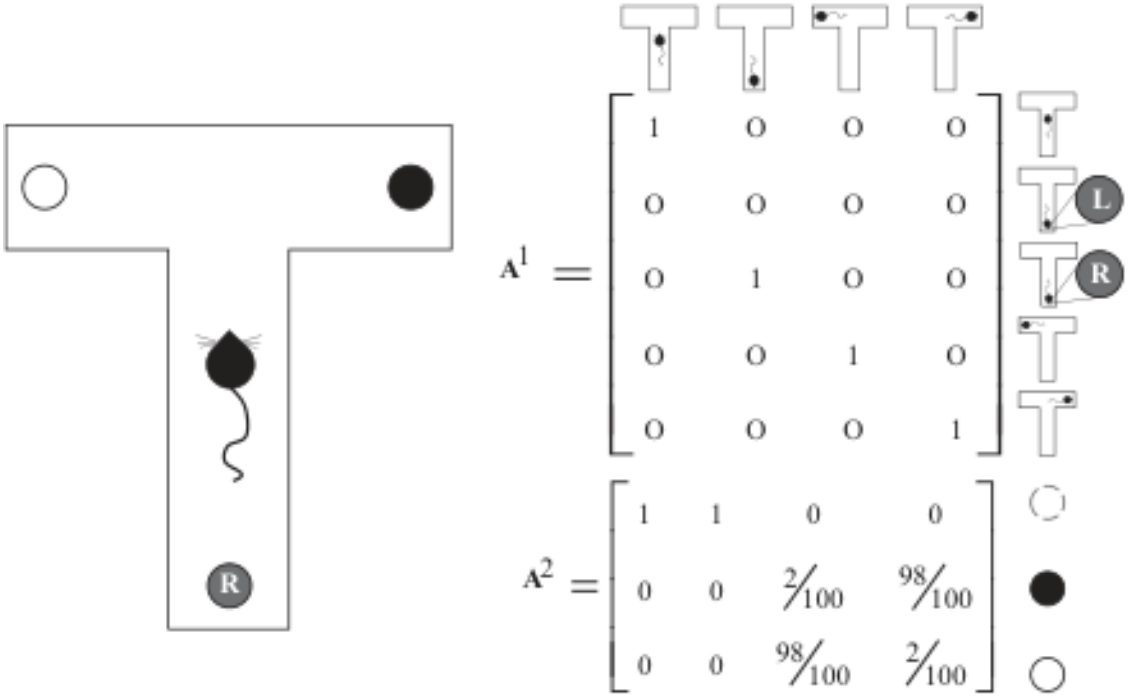
$$G(\pi) = \underbrace{\mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]] - H[Q(\tilde{o} \mid \pi)]}_{\text{负认知价值} -I(\pi)} \\ \underbrace{- \mathbb{E}_{Q(\tilde{o}|\pi)}[\ln P(\tilde{o} \mid C)]}_{\text{实用价值}} . \tag{7.4}$$

将期望自由能分解为认知价值和实用价值，突出了收集信息的认知驱动力，以及实现先验信念（图 7.3 中的 C）的实用驱动力. 下一节会尝试给出更深入的认知价值直觉；简单说，它就是特定策略下预期获得的信息量. 实用价值的形式，实际上把在所有策略上平均的结果概率当作先验. 因此，后果与此先验一致的策略具有较低期望自由能，也就更可能被采用. 更直观地说，如果认为某种观测极可能出现，我们就会行动，来实现自己将遇到这种观测的信念. 因而可以把结果的对数概率，看作相当于最优控制理论、强化学习等其他形式体系中的效用函数. 效用与信息价值作为期望自由能的两个成分共同出现，这意味着无需另行操心如何平衡探索与利用：二者都服务于优化同一个函数.

为理解 T 形迷宫中这一过程如何展开，需要像上面的 HMM 那样形式化地指定生成模型. 图 7.4–7.6 给出了构成 T 形迷宫生成模型的似然与转移概率. 我们将稍详细地说明，因为这个最小例子提供了读者构建自身生成模型的基础模块. 首先决定结果模态的数量，它们表示模型要解释的感觉数据；这决定须指定多少个 A 矩阵. 这里有两种模态：一种表示大鼠在迷宫何处的外感受数据（A^1），另一种是“是什么”模态，可表示大鼠找到可食用的吸引刺激时体验到的内感受数据（A^2）. 各模态的水平，即其中可能发生的备选观测，决定各 A 矩阵的行. 下一步，决定用多少个隐状态因子解释这些数据，这也就是所需 B 矩阵的数量. 这里考虑两个因子：大鼠在迷宫中的位置，以及情境，即吸引刺激位于左侧还是右侧. 二者分别有四个和两个水平. 现在必须为隐状态的每种组合指定各结果的概率. 情境 1 见图 7.4，情境 2 见图 7.5.

对第一种模态，A^1 以概率一把各位置关联到某个结果. 根据情境不同，线索位置可能关联向左或向右的线索. 内感受模态 A^2 把起点和线索位置关联到中性结果；当情境与大鼠进入的迷宫臂匹配时，找到吸引结果的概率为 98%. 技术上说，这些 A 矩阵是张量，因为其元素由结果、位置、情境三个数指定，矩阵则只由行、列两个数指定.

接着指定转移概率. B 矩阵给出从某个状态（列）到另一个状态（行）的转移概率，它取决于策略 π 的选择；分别指定迷宫中大鼠位置的转移（B^1）和情境的转移（B^2）. 图 7.6 展示可控的 B^1 转移，每个矩阵给出不同动作选择（以下标表示）下的概率. 它



$$A^1_{\text{情境 }1} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad A^2_{\text{情境 }1} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 2/100 & 98/100 \\ 0 & 0 & 98/100 & 2/100 \end{bmatrix}.$$

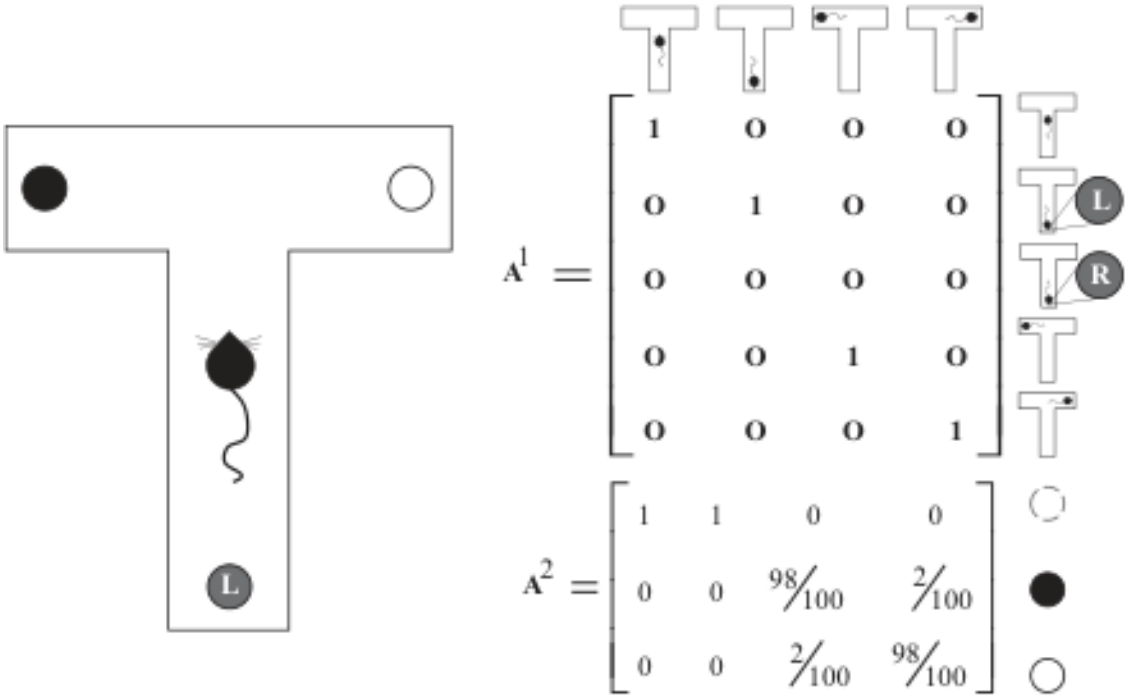
列依次为：起点、线索位置、左臂、右臂；A^1 行依次为起点、左线索、右线索、左臂、右臂；A^2 行依次为无刺激（虚线圆）、吸引性刺激（实心圆）、厌恶性刺激（空心圆）. 本图情境 1 的右臂吸引性刺激概率为 98/100；保留其与附录 C 情境 1 代码奖励方向的源冲突.

图 7.4: 情境 1 的似然. 左：T 形迷宫的线索与刺激配置，吸引刺激在右，厌恶刺激在左. 右：似然或观测模型指定从位置到外感受线索（A^1）和内感受线索（A^2）的概率映射. 每个矩阵元素都是相应行末所示结果的概率，条件为情境 1 和图示位置. 原文将位置说成由 “行” 指示；图中位置实际位于列顶，见译稿问题记录. 外感受结果是与各位置相关的视觉或本体感受输入，其中线索位置可产生向右或向左的线索. 内感受结果为无刺激（虚线轮廓圆）、吸引刺激（实心圆）或厌恶刺激（空心圆）.

们允许从任意位置移到任意其他位置，但两个迷宫臂除外，因为它们是吸收态. 也就是说，一旦到达那里，无论选择什么动作，大鼠都必须留在那里. 相比之下，大鼠不能控制情境，即不能决定自己处于图 7.4 的情境 1，还是图 7.5 的情境 2. 情境随时间不变，可用单位矩阵表示：

$$\mathbf{B}_{\pi}^{2} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}. \tag{7.5}$$

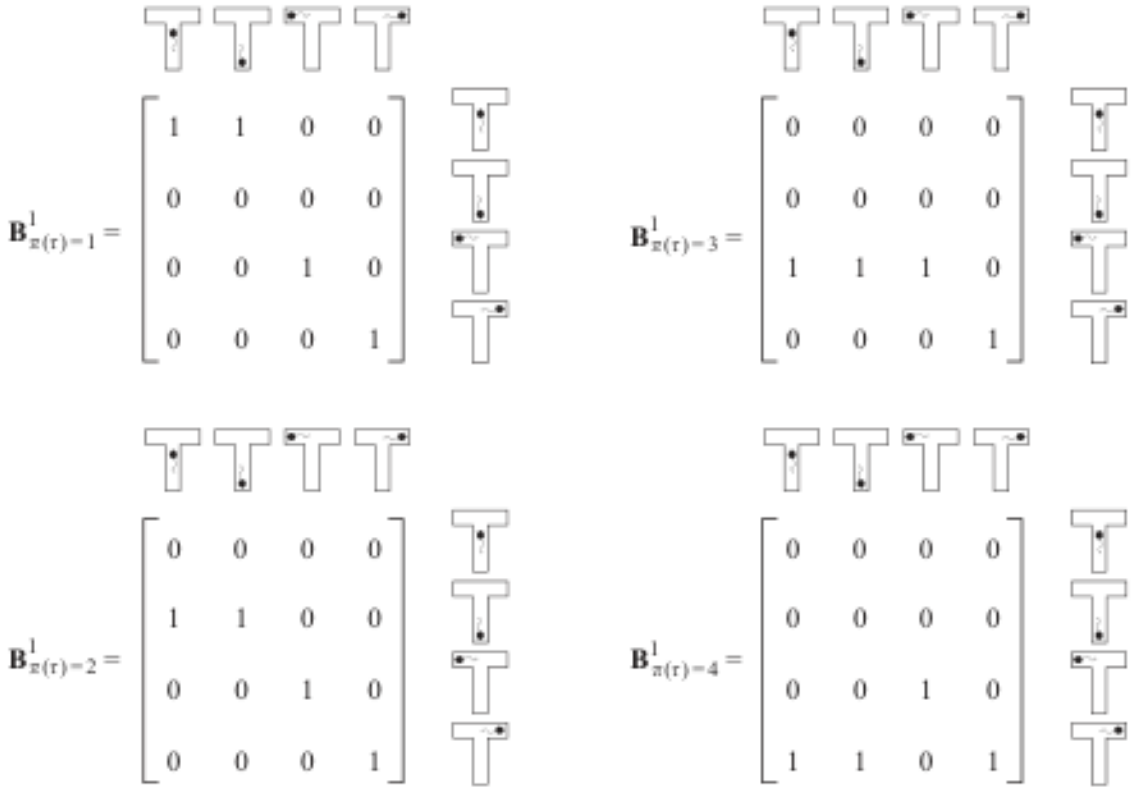
这里每一列和每一行，分别对应以图 7.4 或 7.5 标识的情境状态. 无论开始于哪个情境，都会随时间保持不变，即转移到自身，而且无论选择何种策略都是如此.



$$A^{1}_{\text{情境 2}} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad A^{2}_{\text{情境 2}} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 98/100 & 2/100 \\ 0 & 0 & 2/100 & 98/100 \end{bmatrix}.$$

行、列顺序与图 7.4 相同；情境 2 将左右线索及两臂刺激的概率对换.

图 7.5: 情境 2 的似然. 与图 7.4 几乎相同，但厌恶刺激与吸引刺激互换. 这一点体现在外感受结果在线索位置的概率，以及内感受结果在左右两臂的概率中.



$$\mathbf{B}^1_{\pi(\tau)=1} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad \mathbf{B}^1_{\pi(\tau)=3} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{B}^1_{\pi(\tau)=2} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \qquad \mathbf{B}^1_{\pi(\tau)=4} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{bmatrix}.$$

列表示转移前位置，行表示转移后位置；均依次为起点、线索位置、左臂、右臂. 动作 1–4 分别指向这四个位置，已进入左右臂时仍留在该臂（吸收状态）.

图 7.6: 不同位置之间移动的可控转移概率. 四个矩阵各对应大鼠可选择的一个备选动作，允许从任意状态（左右两臂除外）移到任意其他状态. 左右两臂是吸收态，大鼠一旦进入就必须留在那里.

C^1 向量给出该模态各结果的先验偏好；除了对起点略有厌恶（-1），偏好均匀. C^2 向量指定对吸引刺激的偏好（$+6$）和对厌恶刺激的厌恶（-6）；两种刺激均未出现时视为中性（0）：

$$\begin{aligned}\mathbf{C}^1 &= \sigma([-1,0,0,0,0]^\intercal),\\ \mathbf{C}^2 &= \sigma([0,6,-6]^\intercal).\end{aligned} \tag{7.6}$$

这些向量中元素的顺序，对应相应 A 矩阵各行的顺序. softmax 函数 σ 允许用正值、负值，即未归一化的对数概率，来指定偏好，再将其转成概率；既保留对数概率的差值或相对概率，又保证归一化. 实际上，这一形式意味着：在大鼠的生成模型下，吸引刺激被认为比中性刺激大约可能 $e^6 \approx 400$ 倍. 这是十分强的偏好，意味着大鼠相信自身行动更可能导致吸引结果. 这种关于行动推断的约束，对后续行为至关重要. 最后，D 向量指定初始状态的先验概率：

$$\begin{aligned}\mathbf{D}^1 &= [1,0,0,0]^\intercal,\\ \mathbf{D}^2 &= \tfrac{1}{2}[1,1]^\intercal.\end{aligned} \tag{7.7}$$

其元素顺序与 B 矩阵相同. D^1 表示确信从迷宫中央开始，D^2 表示初始时两种情境，即图 7.4、7.5，被认为等可能.

图 7.7 展示反演图 7.4–7.6 生成模型后发生的情况. 上排展示观察大鼠行为时会看到的现象：它从中央出发，先到信息性线索处. 原因是该位置有高认知价值，即在这里取得的观测可能消除关于情境的不确定性. 看到指示左侧情境的线索（原文括注 “情境 1”）后，大鼠选择迷宫左臂，找到奖赏刺激.[7] 这一步由赋予该位置的高实用价值驱动. 下方各图展示这个简单试验中的信念更新. 与图 7.2 一样，其表示形式对应测量理想化大鼠的神经元活动时预期会观察到的量，即放电率与局部场电位（LFP）. 注意第二个时间步，即大鼠到达信息性线索位置时，信念迅速变化，以及与此相关的 LFP，见虚线.

7.4 信息寻求

前述模拟（原文指第 7.2 节）展示了一个简单的探索—利用权衡：先搜寻信息，直到不确定性消除，再利用所得推断满足先验偏好.[8] 本节更详细地展开认知价值的概念.

[7] 译注：此处原文的 “context 1” 与图 7.4 中右侧奖赏的情境 1 不符；图 7.7 及其图注显示左侧奖赏，对应图 7.5 的情境 2. 保留原文括注并指出冲突，未据此更改模型.

[8] 译注：这里所述迷宫模拟在第 7.3 节；原文印作 7.2 节.

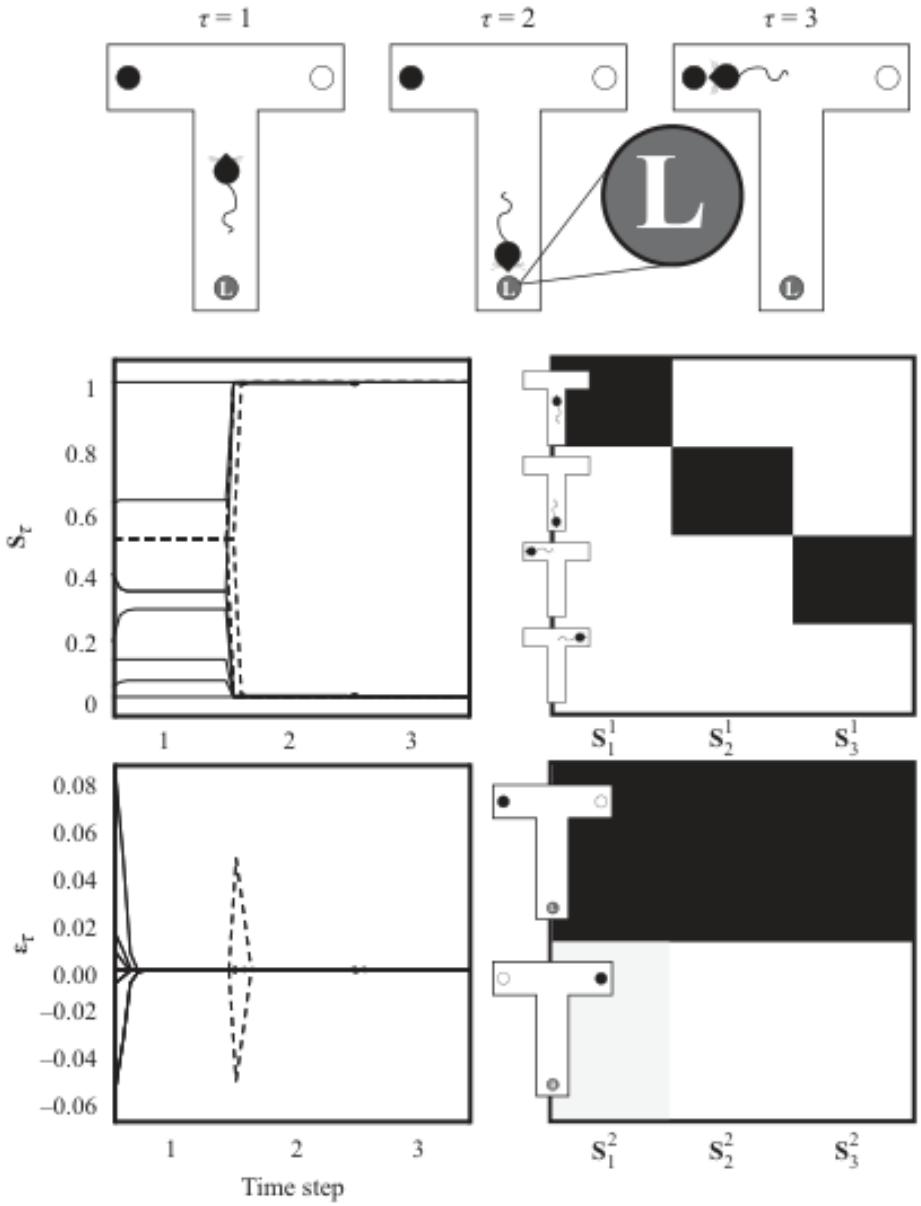


图 7.7: 模拟大鼠在 T 形迷宫中觅食时的认知行为与实用行为. 大鼠从中央出发，随后选择采样下臂的信息性线索. 该位置具有最高认知价值，因为观测此处线索能揭示大鼠处于哪个情境，即奖赏在右还是在左. 观测线索后，大鼠迅速更新信念 s，诱发 LFP（ε）. 没有更多不确定性可消除后，大鼠选择实用价值高的选项，前往左臂. 右侧两图展示试验结束时大鼠对过去各时刻所持的信念，即回溯信念，并非作出决策那一刻的信念. 它正确地相信，自己从中央出发，到线索臂，再到左臂. 对情境隐状态因子，它相信始终处于左侧情境. 图内 Time step：时间步.

如式 (7.4) 所示，它由两项组成：

$$
\begin{aligned}
\underbrace{I(\pi)}_{\text{认知价值}} &= \underbrace{H[Q(\tilde{o} \mid \pi)]}_{\text{后验预测熵}} - \underbrace{\mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]]}_{\text{期望模糊度}} \\
&= \underbrace{D_{\mathrm{KL}}[P(\tilde{o} \mid \tilde{s})Q(\tilde{s} \mid \pi) \| Q(\tilde{o} \mid \pi)Q(\tilde{s} \mid \pi)]}_{\text{互信息}} \\
&= \underbrace{\mathbb{E}_{Q(\tilde{o}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \pi, \tilde{o}) \| Q(\tilde{s} \mid \pi)]]}_{\text{信息增益、显著性、贝叶斯惊异}}, \\
Q(\tilde{s} \mid \pi, \tilde{o}) &\triangleq \frac{P(\tilde{o} \mid \tilde{s})Q(\tilde{s} \mid \pi)}{Q(\tilde{o} \mid \pi)}.
\end{aligned} \tag{7.8}
$$

两项分别为后验预测熵和期望模糊度；下方给出它们与其他重排形式的对应. 为获得直观理解，考虑一个视觉范式：备选眼跳 π 导致不同注视位置 s 之间的不同转移. 隐状态除注视位置外，还包含各位置刺激的身份. 刺激与注视的组合产生视觉及本体感受后果 o. 因而后验预测熵可解释为 “若作此眼动，我会看见什么” 的离散程度或不确定性. 对科学家而言，它量化实施某个实验后可能得到哪些数据的不确定性. 从这一角度，应选择后验预测熵最大的眼跳或实验，因为它们提供最大的消除不确定性的潜力. 如果对结果已有高度确信，实施实验便一无所获.

但是，预测熵只说明不确定性的总量，并不说明其中有多少实际上可消除. 对随机生成的数列，我们总不确定下一个数是什么，但凝视它们并不能消除对其生成过程的不确定性. 这就需要期望模糊度，它量化观测与状态彼此独立的程度. 如果状态总产生相同的观测，此量为零；如果像随机数发生器那样，状态与结果没有关联，此量便最大. 在视觉领域，这意味着最佳眼跳应朝向照明良好的刺激，因为此时 “若看向这个刺激，会看见什么” 的模糊度很小. 合起来说，最佳眼跳，即知觉实验，应面对最多有待消除的不确定性（后验预测熵），前提是该不确定性能够被消除（负模糊度）. 有趣的是，其形式与统计学中按信息增益评价实验设计的表达式完全相同（Lindley 1956）.

图 7.9 展示在眼跳范式（Parr and Friston 2017b）中，模拟操纵模糊度和后验预测熵的结果. 四个刺激以方块表示，各自可随时改变颜色；其上叠加模拟的眼动追踪轨迹，仿佛测量实验参与者正在看哪里. 关键是，把结果的先验信念设为均匀，即不含实用价值，从而排除基于偏好的选择. 因此，每次眼跳都被选择为最大化认知价值. 当生成模型把四个刺激视为等同时，左图中各刺激被采样的频率大致相同. 但我们可以调节各刺激的不确定性，见框 7.1. 如果通过增大相应 A 矩阵非对角元素，把某个刺激设为具有更大模糊度，那么中图中的这个方块就被忽略. 这正是著名的 “路灯” 效应（Demirdjian et al. 2005）：隐喻有人深夜丢了钥匙，可能先在路灯下寻找；并非那里最可能有钥匙，而是那里最容易找到高质量、不模糊、能够消除不确定性的信息. 模拟中，模糊的、例如照明不佳的方块被忽略，在计算机中再现了路灯效应.

框 7.1：不确定性与精确度

原文以图 7.7 的例子引入精确度，这是本书的一项重要概念. 精确度是方差的倒数，度量对给定概率分布的确信程度，与分布的负熵密切相关：

$$-H[P(s)] = \mathbb{E}_{P(s)}[\ln P(s)].$$

要参数化一个分布，使其可以更精确或较不精确，一种简单方法是使用具有逆温度参数 ω 的 Gibbs 形式：

$$P(s \mid \omega) = \mathrm{Cat}(\sigma(\omega \ln \mathbf{D})).$$

注意精确度乘在对数先验上，因此可以解释为增益控制装置，即放大神经信号，而非加到信号上. 图 7.8 展示给定 D 时改变 ω，概率分布如何变化，每个柱表示一种备选状态的概率. 注意精确度越高，置信度越高.
这类参数化可用于 POMDP 的任意分布. 此外，还可以定义精确度的先验，并像其他潜变量一样，通过自由能最小化来推断它. 假定先验为 Gamma 分布，排除精确度的负值，可得以下更新，细节见附录 B：

$$P(\omega) = \Gamma(1, \beta_\omega), \qquad Q(\omega) = \Gamma(1, \boldsymbol{\beta}_\omega),$$
$$\dot{\boldsymbol{\beta}}_\omega = (\mathbf{D}^{\beta_\omega^{-1}} - \mathbf{s}) \cdot \ln \mathbf{D} + \beta_\omega - \boldsymbol{\beta}_\omega.$$

越来越多的研究认为，这些精确度参数的生物学基础可能是设定神经反应增益的神经调质系统. 第 5 章讨论将这些参数关联到特定神经化学物质的证据.



图 7.8: 给定分布 D，改变精确度 ω 后，各备选状态的概率. 原书仅标图号，无额外文字图注.

相反，若让左下方块的转移更难预测，右图展示了所发生的情况；原文此处指图 7.8，实际对应图 7.9. 我们会很快积累关于该位置的不确定性，使后验预测熵提高，而模糊度不变. 因此，对它的注视更频繁，因为那里始终有新的不确定性可消除. 直观而言，若知道某物动力学高度可预测，无需频繁观看，就能确信其状态；若它可能在自己看向别处时改变，就值得回头检查. 这些模拟旨在给出认知价值两个部分的直觉，说明期望自由能最小化如何确保我们主动选择感觉数据，以了解世界.

7.5 学习与新奇性

第 7.2–7.4 节给出了主动推断大多数实际应用所需的全部内容. 但我们一直假定生成模型已知，且不会由于学习而改变. 某些应用可能需要考虑在实验中如何学习生成模

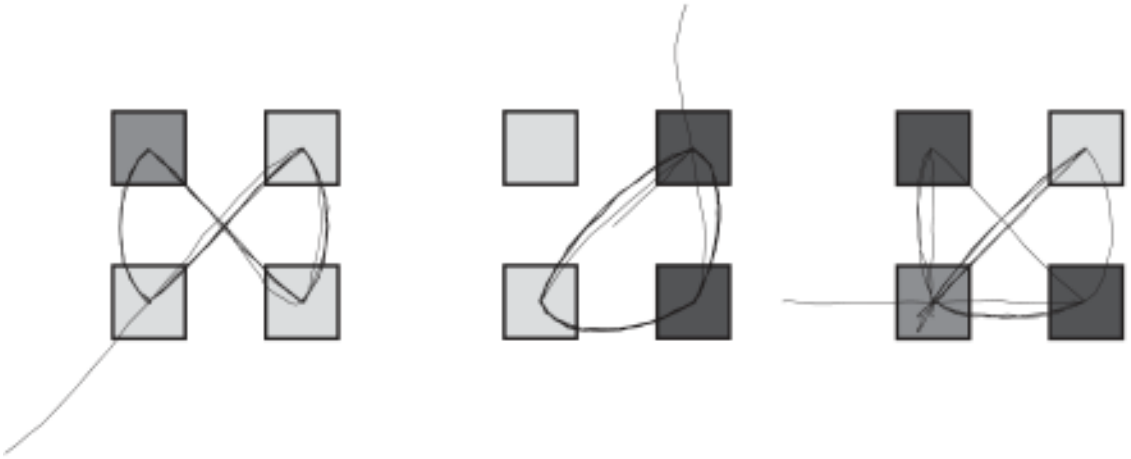


图 7.9: 模拟的认知性视觉搜索范式（Parr and Friston 2017b），四个刺激位置上叠加合成眼动追踪轨迹. 每个阴影方块关联一个可预测性不同的转移矩阵，以及一个模糊程度不同的似然矩阵. 左：四个位置的转移与似然同样可预测时，各位置被采样的频率约相同. 中：左上方块被指定为精确度较低、即更模糊的似然映射时，观察者对其表现出回避. 右：左下方块的转移概率被设为更不确定时，它在认知上更具吸引力.

型的一个或多个部分，例如 A 或 B 矩阵；或更广义地，给定某些数据，如何优化生成模型自身的结构（Friston, FitzGerald et al. 2016）. 这样，主动推断就扩展为主动学习：描述状态信息增益的显著性，由处理参数不确定性消除的新奇性（novelty）补充；这些参数可为式 (7.1) 的 A 矩阵元素、式 (7.2) 的 B 矩阵元素，或模型的其他参数.[9] 这些信念现在可以随时间变化，而非像此前假定的那样固定（Schwartenbeck et al. 2019）. 为此，首先须如图 7.10 那样，扩展生成模型，纳入关于这些模型参数的信念.

概念上，在生成模型中包含参数信念，就能把学习视为另一种贝叶斯推断，即由模型参数的先验信念走向后验信念. 这突出了知觉与学习的根本相似性：知觉可描述为反演生成模型、从观测推断隐状态；学习同样可描述为反演生成模型、纳入参数信念，只是这种反演通常运行在较慢时间尺度上.

[9]译注：源文在这里把显著性指向式（7.5），该式实际是情境转移单位矩阵；相应信息增益表达式见式 (7.8).

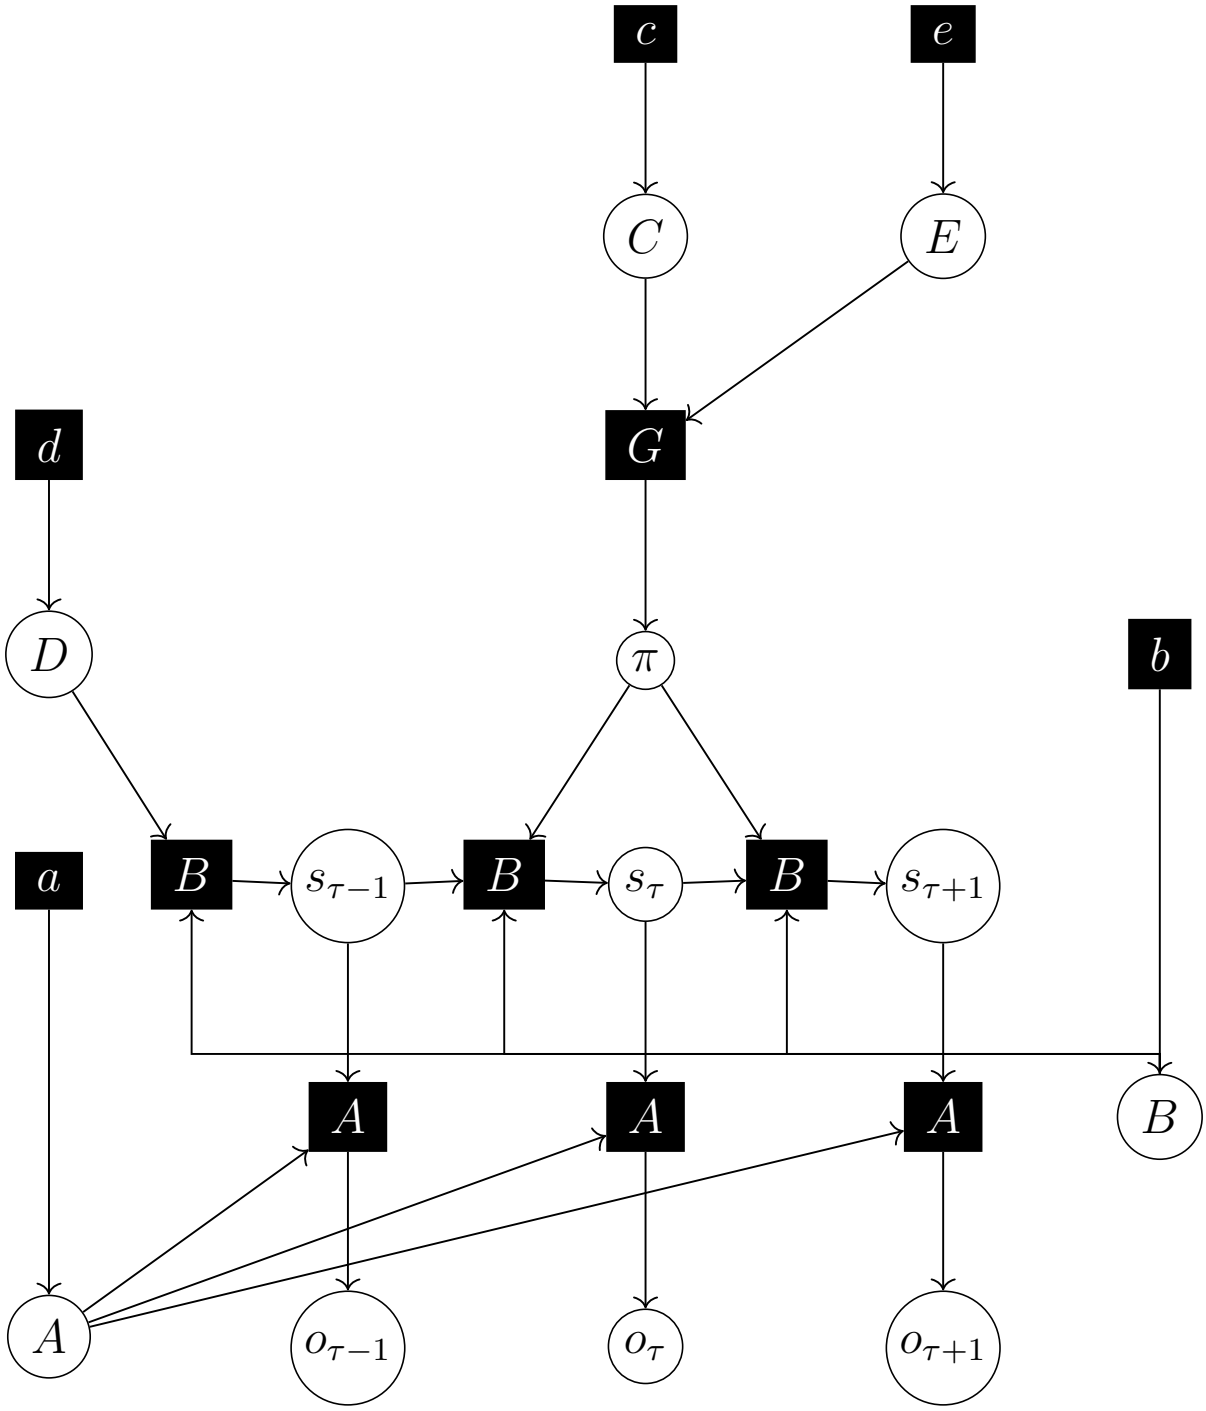


图 7.10: 学习的生成模型沿用图 7.3 的 POMDP 结构，但每个隐状态的先验现在依赖圆圈中的变量，它们自身也配有先验信念. 先验为与此前范畴分布共轭的 Dirichlet 分布，见框 7.2. 给定状态时结果的似然还依赖对所有时间点相同的变量 A；转移概率以变量 B 为条件，偏好依赖 C，初始状态依赖 D，固定形式策略先验依赖 E. 将模型参数的先验信念显式化，突出了推断和学习都是自由能最小化过程，但二者不同：推断优化关于世界当前状态 s 的信念，包括关于自身行动方式 π 的信念；学习优化这些变量之间关系 A, B, C, D, E 的信念. 后者变化慢得多，且可能只有在状态已被推断之后才学习. 下文讨论层级生成模型时会再回到这种时间尺度分离.

框 7.2：共轭先验

建立图 7.10 形式的生成模型时，必须仔细选择适合先验信念的分布，通常是与似然相关联的共轭先验分布. 共轭先验意味着，用它进行贝叶斯推断时，后验信念仍属于相同类型的分布. 例如由贝叶斯规则，

$$P(D \mid s) \propto P(D)P(s \mid D).$$

如果 $P(s \mid D)$ 为范畴分布，选择与范畴分布共轭的 Dirichlet 分布作为 $P(D)$，便能保证 $P(D \mid s)$ 也是 Dirichlet 分布. 形式上，

$$\left.\begin{aligned} P(D) &= \mathrm{Dir}(d), \\ P(s \mid D) &= \mathrm{Cat}(D) \end{aligned}\right\} \implies P(D \mid s) = \mathrm{Dir}(\mathbf{d}).$$

选择合适先验类型的最简单办法，是查明所用似然分布的共轭先验. 对这里的范畴分布，参数信念应采用 Dirichlet 分布，见框 7.2. 加入这些先验信念后，就可以优化关于生成模型结构的后验信念：像第 4 章处理状态那样，把它们纳入自由能并寻找自由能极小值：

$$\begin{aligned} &\theta = (A, B, C, D, E), \\ &F = \mathbb{E}_{Q(\pi,\theta)}[F(\pi,\theta)] + D_{\mathrm{KL}}[Q(\theta)\|P(\theta)] + D_{\mathrm{KL}}[Q(\pi)\|P(\pi)]. \end{aligned} \tag{7.9}$$

Dirichlet 分布由计数或伪计数参数化，表示某范畴变量被看到多少次；对先验而言，是仿佛已经看到这么多次. 参数更新规则的推导见附录 B. 这里概括 Dirichlet 分布的更新规则和关键性质，聚焦与 A 的先验、后验相关的浓度参数 a 和 $\mathbf{a}$：

$$\begin{aligned} \mathbf{a} &= a + \sum_{\tau} \mathbf{s}_\tau \otimes o_\tau, \\ \mathbb{E}_Q[A_{ij}] = \mathbf{A}_{ij} &\approx \frac{\mathbf{a}_{ij}}{\mathbf{a}_{0j}}, \\ \mathbb{E}_Q[\ln A_{ij}] = \ln \mathbf{A}_{ij} &= \psi(\mathbf{a}_{ij}) - \psi(\mathbf{a}_{0j}), \\ \mathbf{a}_{0j} &\triangleq \sum_{k} \mathbf{a}_{kj}. \end{aligned} \tag{7.10}$$

第一行表示，在一系列观测及关于产生它们的状态信念之后，从先验浓度参数到后验浓度参数的更新. 圈中的叉表示 Kronecker 张量积；对两个向量即外积. 这里产生一个矩阵，各元素是 $\mathbf{s}_\tau$ 与 o_τ 中一对元素的乘积. 这个更新规则可以简单解释为活动依赖的可塑性：当观测到某结果，并有后验信念认为它由某状态导致时，表示二者关系的矩阵元素就增加. 第二行突出把 Dirichlet 浓度参数解释为计数. 对给定状态（列），$\mathbf{a}$ 各元素是对应结果被看到的次数；除以该列元素之和，即观测或伪观测总数，就得到给定该状态时各结果的概率.

为理解这种伪计数方法为何直观上合理，回到本章开头的业余音乐家. 统计她想演奏第一个音符时实际奏对的次数，即首行首列；想演奏第二个音符时奏对的次数，即第二行第二列；依此类推，再除以她想演奏各音符的总次数，最终就会收敛到式 (7.1) 中

A 矩阵的正确数值，即所有预定音符都有 70% 的奏对概率. 计数方法还有一个稍后会回到的重要后果：观测前已有的计数或伪计数数量，告诉我们这次观测有多可能更新信念. 想象抛硬币五次，连续得到五次正面，可能使我们转向支持硬币不公平的假设. 但如果此前已经抛过 100 次，正反面各 50 次，那么最后这五次正面对硬币是否公平的信念就影响很小. 式 (7.10) 第三行给出 Dirichlet 分布的一项有用恒等式：随机变量的对数期望由两个 digamma 函数之差给出；原文将该函数解释为 gamma 函数的导数.[10]

把学习视为推断，突出了主动推断与计算神经科学及机器学习大多数其他方法的一项重要区别. 后者纳入各种被认为生物学上真实或计算上高效的学习规则，例如 Hebb 规则或误差反向传播. 主动推断中控制学习的更新规则则由统计考虑推导，却与生物学动机下的活动依赖可塑性规则非常相似，见上面对式 (7.10) 第一行的讨论. 这体现规范性方法的一项吸引力：从第一性原理出发，解释我们对大脑与行为已知的事情，也解释尚未知晓的事情.

另一项区别是，学习自然被描述为主动过程：生物自主选择最适合改进其生成模型的数据. 当把参数信念纳入模型时，期望自由能会多出一项，这一点由下式可见：

$$
\begin{aligned}
G(\pi) = & \underbrace{D_{\mathrm{KL}}[Q(\tilde{o} \mid \pi) \| P(\tilde{o} \mid C)]}_{\text{风险}} + \underbrace{\mathbb{E}_{Q(\tilde{s}|\pi)}[H[P(\tilde{o} \mid \tilde{s})]]}_{\text{模糊度}} \\
& + \underbrace{\mathbb{E}_{\widetilde{Q}(\tilde{o},\tilde{s},\theta|\pi)}[\ln Q(\theta) - \ln P(\theta \mid \tilde{o}, \tilde{s})]}_{\text{参数信息增益}} \\
= & - \underbrace{\mathbb{E}_{Q(\tilde{o}|\pi)}[D_{\mathrm{KL}}[Q(\tilde{s} \mid \pi, \tilde{o}) \| Q(\tilde{s} \mid \pi)]]}_{\text{显著性}} \\
& - \underbrace{\mathbb{E}_{\widetilde{Q}(\tilde{o},\tilde{s}|\pi)}[D_{\mathrm{KL}}[Q(\theta \mid \tilde{o}, \tilde{s}) \| Q(\theta)]]}_{\text{新奇性}} - \underbrace{\mathbb{E}_{Q(\tilde{o}|\pi)}[\ln P(\tilde{o} \mid C)]}_{\text{实用价值}} .
\end{aligned}
\tag{7.11}
$$

显著性与实用价值已存在于式 (7.4)，但新奇性是新增项. 最后一个等号后的重排突出了显著性与新奇性的关系：显著性之于推断，正如新奇性之于学习. 二者都表达进行知觉实验，即执行策略中的行动后，预期发生的信念改变. 如同科学实验，收集数据后的信念改变越大，实验越好. 回到抛硬币并积累计数的类比，可以得到有用的启示. 如果有两枚硬币，可以任选一枚来抛，抛此前只抛过五次的硬币，比抛此前已抛 100 次的硬币，能引起更大的信念变化. 前者更不熟悉，因此抛它具有更高新奇性. 类似地，如果先验信念十分确信，仿佛某事已观察过许多次，那么探查这些变量的策略，就比探查那些信念较不确信的变量的策略具有更少新奇性.

为说明实际运行方式，设想一只视力极短的生物站在铺砖地面上，只能看见脚下砖块的颜色，每次只能移动一块砖. 对含许多砖块、足够大的空间，把每块砖的颜色表示为不同隐状态会非常昂贵. 但可用更简单的模型：只让隐状态关联位置，只让结果关联颜色，就能在由位置生成有色砖块的 A 矩阵中，高效表示“如果去那里，会看见什么”的信念. 通过积累 Dirichlet 参数，见式 (7.10)，生物可依据观测优化这些信念. 可以把它解释为突触记忆，而非在表示某砖块颜色信念的神经元中维持持续活动. 在这样的生成模

[10]译注：原文括注为“derivative of a gamma function”；标准定义为 $\psi(x) = \frac{d}{dx} \ln \Gamma(x)$，即对数 Gamma 函数的导数. 原有括注意思已明示，公式按源保留.

型中，所有不确定性都在似然分布的参数中；于是值得看看没有任何偏好，即式 (7.11) 的新奇性项主导策略选择时，会发生什么.

图 7.11 展示由 64 块黑白砖构成的简单环境模拟. 每访问一块砖，都会通过积累 Dirichlet 参数，更新关于该位置观察到黑色或白色的似然信念. 较大的 Dirichlet 参数排除了大幅信念更新，因此期望自由能最小化所给出的消除新奇性的驱动力，使模拟生物避免此前访问过的任何位置. 同样原理可用于许多其他范式；例如把路径重新解释为眼跳扫描路径，就可应用于主动视觉采样. 在主动视觉领域，该方法已用于模拟目标划消任务引起的视觉搜索行为（Parr and Friston 2017a）. 随后，在此情境下积累 Dirichlet 参数所需的短时可塑性，也已得到证据支持（Parr, Mirza et al. 2019）.

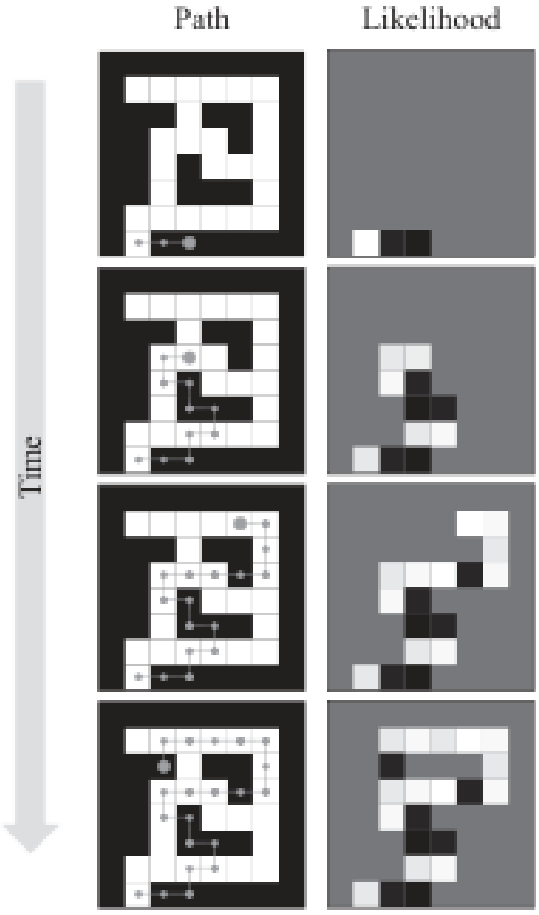


图 7.11: 在黑白砖组成的简单世界中探索的合成生物，展示主动学习（Bruineberg et al. 2018；Kaplan and Friston 2018）. 左：行进路径，以及哪些砖白、哪些砖黑；点表示访问过的位置. 右：生物关于前往各位置会看到什么的信念矩阵，以归一化 Dirichlet 计数表示. 如果确信相应砖块为白或黑，A 矩阵单元就为白或黑；若颜色不确定则为灰. 这些信念通过期望自由能的新奇性项影响路径. 对信念确信的位置，消除不确定性的机会相对少，因此不再访问. 换言之，“返回抑制” 现象（Posner et al. 1985）自然从期望自由能最小化中涌现. 图内 Path：路径；Likelihood：似然；Time：时间，向下增加.

正如从推断推广到学习，还可以至少再进一步考虑结构学习：不只优化模型参数，还在启用更多或更少参数的不同模型之间进行选择. 框 7.3 给出一种方法，对备选假设

模型进行高效的事后比较. 它已被用作睡眠（Friston, Lin et al. 2017）与静息自发活动（Pezzulo, Zorzi, and Corbetta 2020）的隐喻：不收集新数据，但模型结构仍可得到精炼和简化.

框 7.3：结构学习与模型约简

原文称第 7.4 节的讨论涉及一种重要但有限的参数学习；相应学习内容实际见第 7.5 节. 了解世界结构的下一层复杂性超越参数优化，转而问：是否应扩展或修剪模型结构？这可以表述为模型比较问题（Friston, Lin et al. 2017）. 例如，如果去掉似然矩阵的某些元素，自由能会增加还是减少？比较具有和不具有这些元素的模型即可回答. 但显式反演多个模型可能十分昂贵. 幸运的是，有一种称为贝叶斯模型约简的高效方法（Friston, Litvak et al. 2016；Friston, Parr, and Zeidman 2018），只需反演一个完整模型. 一般地，完整模型与具有备选先验（波浪号表示）的模型，可以用下式比较：

$$\Delta F = F[\widetilde{P}(\theta)] - F[P(\theta)] = \ln \mathbb{E}_{Q(\theta)}\left[\frac{P(\theta)}{\widetilde{P}(\theta)}\right],$$
$$\widetilde{Q}(\theta) \propto \exp\big(\ln Q(\theta) + \ln \widetilde{P}(\theta) - \ln P(\theta) + \Delta F\big).$$

对第 7.5 节的 Dirichlet 先验，它写成以下形式，其中 B 是多元 beta 函数：

$$\Delta F = \ln \mathrm{B}(\widetilde{\mathbf{d}}) - \ln \mathrm{B}(\mathbf{d}) + \ln \mathrm{B}(d) - \ln \mathrm{B}(\widetilde{d}),$$
$$\widetilde{\mathbf{d}} = \mathbf{d} + \widetilde{d} - d.$$

这种模型约简形式，对于理解睡眠期间可能发生的离线模型优化也许很重要. 第 8 章讨论同时含离散与连续成分的层级模型优化时，将简要回到贝叶斯模型约简.

7.6 层级推断或深度推断

上一节展示了一种生成模型的层级扩展：定义生成模型参数的先验. 图 7.12 给出另一种层级，涉及时间尺度的嵌套. 该层级推断或深度推断的生成模型，可视为图 7.3 浅层模型的层级扩展：低层包含一系列与该图相同的 POMDP，由高层 POMDP 提供情境. 原书用虚线框圈出其中一个低层实例.

重要的是，模型包含在不同时间尺度上演化的变量：高层较慢，低层较快（Friston 2008; Friston, Rosch et al. 2017; Pezzulo, Rigoli, and Friston 2018）. 第一层的 POMDP 在三个时间步上演化，但每条短状态—结果轨迹都取决于第二层的单个状态，而该高层状态会持续整个低层轨迹. 换言之，高层视角下每过一个时间步，低层就会有多个、这里是三个时间步.

为直观理解支持深度时间推断的时间尺度分离，可以想想日常层级的简单例子：阅读. 我们推断单词，单词组成句子，句子组成段落、页面、书籍、图书馆，等等. 若图 7.12 低层的每个状态是单词，那么高层每个状态可以看作句子. 关键是，句子的持续时间跨越序列中任意单个单词的持续时间.

图 7.13 更详细地展示阅读例子，基于 Friston, Rosch et al.（2017），更多细节请参

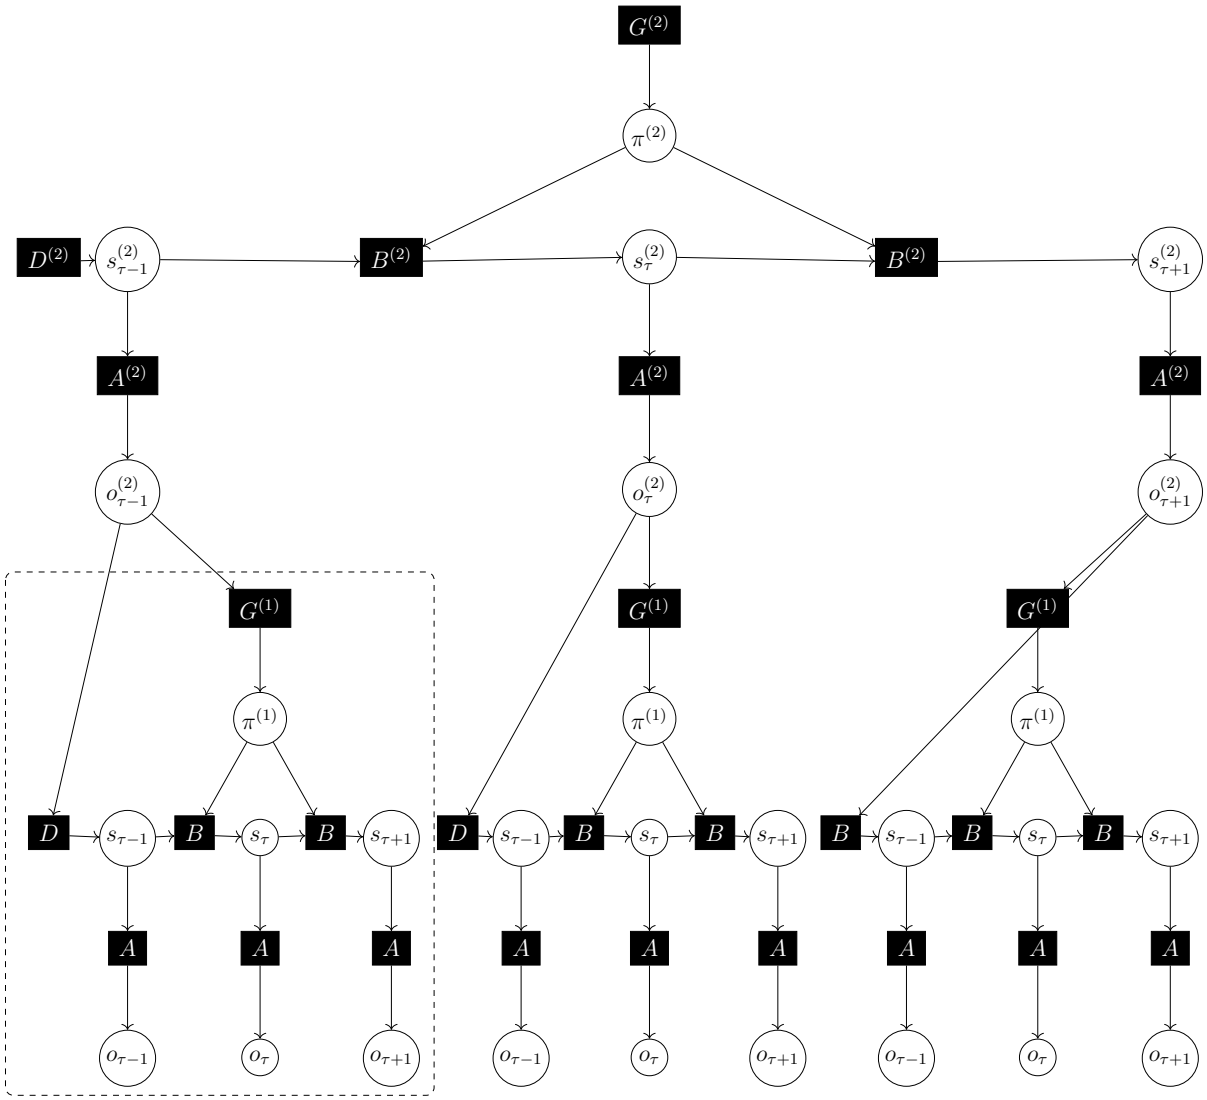


图 7.12: 把图 7.3 的浅层生成模型扩展为在多个时间尺度上演化的层级推断或深度推断模型. 完整模型包含第二层缓慢改变的情境，在第一层较快的尺度上生成一系列短轨迹. 高层和低层的 POMDP 形式相同；唯一区别是高层在时间上横向拉长，且其结果并非直接观测到，而是成为低层的经验先验，由低层生成可观测结果. 各高层结果分别连到下方对应段的初始状态先验因子和期望自由能因子 G，再由 G 指向策略变量，各低层策略分别连到该段两个转移因子. 原图的虚线框仅标识最左低层实例，本重排图恢复该实例的虚线框. 原图最右段的初始因子印为 B，此处照录.

阅该文. 模型结构如图 7.12，表示一种极简单语言中的句子（高层）与单词（低层）. 语言有三个可能单词 flee（逃离）、feed（进食）、wait（等待），可排列成六个可能的四词句子. 如果句子是 “flee, wait, feed, wait”，高层便为第一个低层 POMDP 预测 flee，为第二个预测 wait，依此类推. 低层从基于高层的经验先验 D 开始，它告诉我们哪些单词最合理. 例如，如果初始时图 7.13 上图各句子的分布均匀，则三分之二句子的首词为 wait，另外三分之一为 flee. 因而，在第一个低层 POMDP 的第一个时间步，D 向量就应把这些概率赋给相应单词.

低层单词接着生成观测，即依据当前中央凹注视单词哪一部分而产生的视觉输入. 如图 7.9 的例子，POMDP 允许选择不同中央凹目标，为各假设单词积累支持或反对证据. 它使用的仍是此前的期望自由能最小化过程，因此这里不详述具体注视，只指出，低层每过一个时间步，对当前单词的置信度都会增加. 图 7.13 的序列中，最初几个快速尺度 $\tau^{(1)}$ 的时间步，在低层积累了支持 flee 的证据. 该推断再向上传播，为第一和第四个句子提供证据，因为二者都以这个词开头. 后续时间步，低层积累的证据与两个句子都一致. 到慢尺度 $\tau^{(2)}$ 的第四步，第一个句子预测 wait，另一个候选句子预测 flee. 快尺度推断出 wait 后，慢尺度便推断为第一个句子. 最后一步，模拟选择正确句子，并以正确反馈得到奖赏. 所产生的信念更新可见下方 LFP 图；原文此处指图 7.12，下方 LFP 图实际见图 7.13.

这种深度时间模型已用于模拟阅读（Friston, Rosch et al. 2017）、延迟期工作记忆任务（Parr and Friston 2017c），以及视觉推断的经验先验计算（Parr, Benrimoh et al. 2018）；也用于动机与控制的理论解释（Pezzulo, Rigoli, and Friston 2018）. 原则上，可把模型扩展到任意多层，以描述一个结构深邃、动力学在许多不同时间尺度上展开的世界.

图 7.12、7.13 这类层级模型，与图 7.10 这类学习模型之间，存在有趣的平行. 学习模型可视为层级生成模型，突出较快的推断动力学，即状态信念更新，与较慢的学习动力学，即参数信念更新，之间的时间尺度分离. 图 7.10 与 7.12 的模型还可任意复杂地组合，其中不同层变量间的关系本身也可以学习. 这允许设计越来越复杂的生成模型，以研究系统层面的认知和神经生物学问题.

7.7 小结

本章展示了构建离散时间生成模型的一些方法，用于研究知觉推断、决策与规划、探索与利用的平衡、参数学习与结构学习、新奇寻求等认知和神经生物学问题. 这远非对主动推断中离散模型应用的穷尽总结，但展示了此类建模的关键原理. 上述模型可层级组合，增加参数先验，以及依赖情境的策略先验或偏好先验. 重要的是，无论生成模型简单还是复杂，都始终能通过自由能最小化进行推断，体现了方法的一般性. 主动推断的不同方面在不同生成模型下显现，例如加入模型参数先验后出现新奇寻求；这使我们能够通过设计适合的生成模型，探索开放且不断扩展的认知与生物学问题集合.

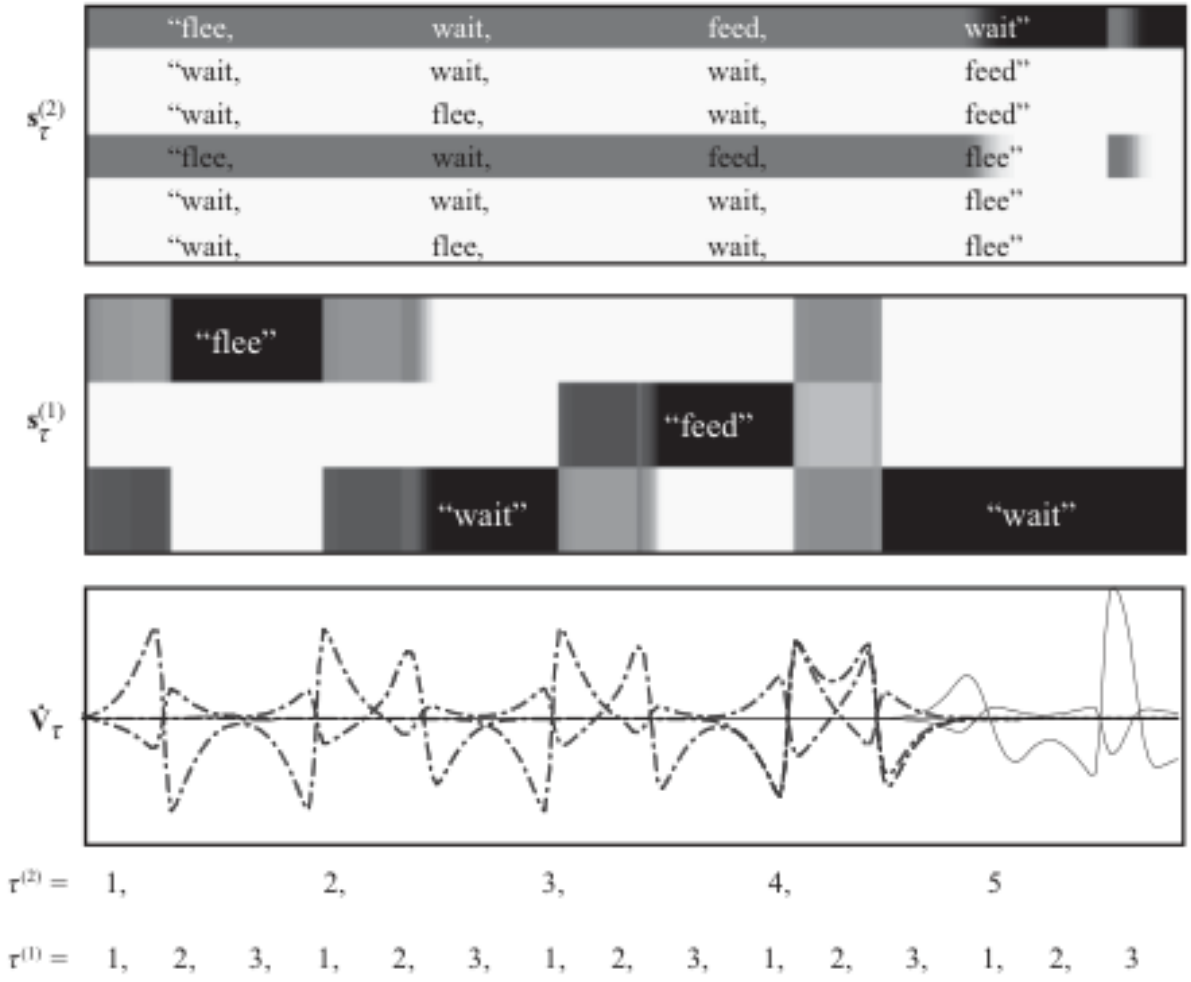


图 7.13: 反演模拟的层级推断模型，在多个时间尺度上产生信念更新. 模型的时间尺度分离为慢尺度 $\tau^{(2)}$ 和快尺度 $\tau^{(1)}$. 高层 $s^{(2)}$ 表示句子，其信念更新比表示单词的低层 $s^{(1)}$ 更慢. 下图：LFP，即对数期望的变化率，与前图的预测误差 ε 成正比. 图内原词 flee：逃离；feed：进食；wait：等待，保留原拼写以呈现视觉字形任务.

Chapter 8

连续时间中的主动推断

万物流变，无物静止.
——Heraclitus，公元前 501 年

8.1 引言

本章补充第 7 章，继续讨论如何构建生成模型. 这里关注连续状态空间模型，它们适合对作用于感觉受体的物理涨落，以及用来改变周围世界的效应器、例如肌肉的连续运动建模. 这类模型应用广泛. 本章说明其使用原理，突出运动控制所用模型的种类及其中起作用的动力系统，并涉及广义同步概念. 最后讨论离散与连续生成模型的协调统一.

8.2 运动控制

如第 4 章所见，支持连续时间主动推断的生成模型，可写成一对随机方程，确定状态 x 如何生成数据 y，以及状态如何依赖某静态变量 v 随时间演化：

$$\begin{aligned} y &= g(x) + \omega_y, \\ \dot{x} &= f(x, v) + \omega_x. \end{aligned} \tag{8.1}$$

这些方程及涨落 ω 的精确度，确定了推断感觉成因所用的模型. 注意式 (8.1) 中没有行动. 如第 6 章所述，行动是生成过程的一部分，而不是生成模型的一部分. 生成模型只处理直接受马尔可夫毯外部状态影响的那些变量. 如果写出现实世界、即生成过程的动力学，就必须纳入行动 u：

$$\begin{aligned} y &= g(x) + \omega_y, \\ \dot{x} &= \mathbf{f}(x, u) + \omega_x. \end{aligned} \tag{8.2}$$

注意，用于定义生成模型，即式 (8.1) 的函数 g、f 及 ω 的精确度，不必与定义生成过程，即式 (8.2) 的相同. 如第 2–4 章所见，行动改变感觉数据，使自由能最小化. 因而不必在生成模型中显式写出行动的动力学，它会从为式 (8.1) 各项所作的选择中涌现. 为获得直觉，先从十分简单的生成模型开始：

$$\begin{aligned} g(x) &= x, \\ f(x, v) &= v - x. \end{aligned} \tag{8.3}$$

式 (8.3) 表示隐状态代表数据的期望值，其动力学与简单的点吸引子一致. 所谓吸引子，是说当 $x < v$ 时，x 的期望变化率为正，反之亦然. 因而 x 总流向 v；v 是吸引点或不

动点. 为生成数据，定义简单生成过程：

$$\begin{aligned} g(x) &= x, \\ \mathbf{f}(x,u) &= u. \end{aligned} \tag{8.4}$$

最小化自由能意味着，行动会改变，以实现式 (8.3) 的预测. 如果 μ 是 x 的期望值，那么使预测数据 $g(\mu)$ 与观测数据 y 的差最小的行动，就是令 $u = v - \mu$. 这表达了 “平衡点假说”（Feldman and Levin 2009）：运动控制由反射弧实施，反射弧只是将肢体拉向下行运动信号设定的平衡点. 主动推断中，这些信号是预测，具体为关于肢体或眼睛期望位置等的本体感受预测（Adams, Shipp, and Friston 2013）. 因而运动控制来自行动对本体感受预测的实现，示意见图 8.1. 注意，此方案不必指定其他运动控制形式体系广泛使用的逆模型，即从期望后果映射到实现它们所需运动指令的模型（Wolpert and Kawato 1998）.

式 (8.3) 是生成模型中可使用的最简单吸引子系统，但在适用更真实牛顿动力学的许多情境中，它过于简单. 更复杂的模型认识到，肌肉产生的力改变速度，即引起加速度，而非直接改变位置. 下面以 x_1 为位置、x_2 为速度明确表达：

$$f(x,v) = \begin{bmatrix} x_2 \\ \frac{\kappa}{m}(v - x_1) \end{bmatrix}. \tag{8.5}$$

这相当于遵守 Hooke 定律的弹簧动力学. 位置的变化率，即第一个分量，就是速度；速度的变化率，即第二个分量，与当前位置和点 v 的距离成正比，比例常数是质量 m 与弹簧常数 κ 之间的比值.[11] 两边乘以质量，连接 v、x_1 的弹簧所产生的力 $\kappa(v - x_1)$，就等于质量乘速度变化率.[1] 这就是牛顿第二定律. 换言之，可以写一个生成模型，预测仿佛有弹簧把肢体拉向期望位置时会展开的动力学；预测此牛顿力学产生的本体感受数据，就能实施实现这些预测的运动.

图 8.1 的公式转录（译者排版补充）

$$\begin{aligned} \dot{\tilde{\mu}}_x &= D\tilde{\mu}_x + \nabla_{\tilde{\mu}_x}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x + \cdots, \\ \tilde{y} &= \tilde{g}(\tilde{x}) + \tilde{\omega}_y, \qquad\qquad \tilde{\varepsilon}_y = \tilde{y} - \tilde{g}(\tilde{\mu}_x), \\ \dot{u} &= -\nabla_u\tilde{y}(u)\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y. \end{aligned}$$

8.3 动力系统

如第 8.2 节所述，连续时间主动推断适合刻画运动. 更一般地，它适合指定非线性动力系统的生成模型，此时将时间和空间离散化效率较低. 最简单的动力系统是式 (8.3) 的吸引子，而更复杂系统可以产生丰富得多的行为. 本书篇幅有限，无法充分介绍运用更复杂动力系统建立模型的大量工作；一些关键进展见表 8.1. 这里聚焦理解这些系统所需的少数原理，简述两类用于构建生成模型的动力系统：Lotka–Volterra 动力学与 Lorenz 系统. 前者可刻画动力学具有序列性的系统，后者表示混沌系统.

[11] 译注：源文先提质量再提弹簧常数，但明确公式为 κ/m，此处不把文字顺序解释为相反的商.

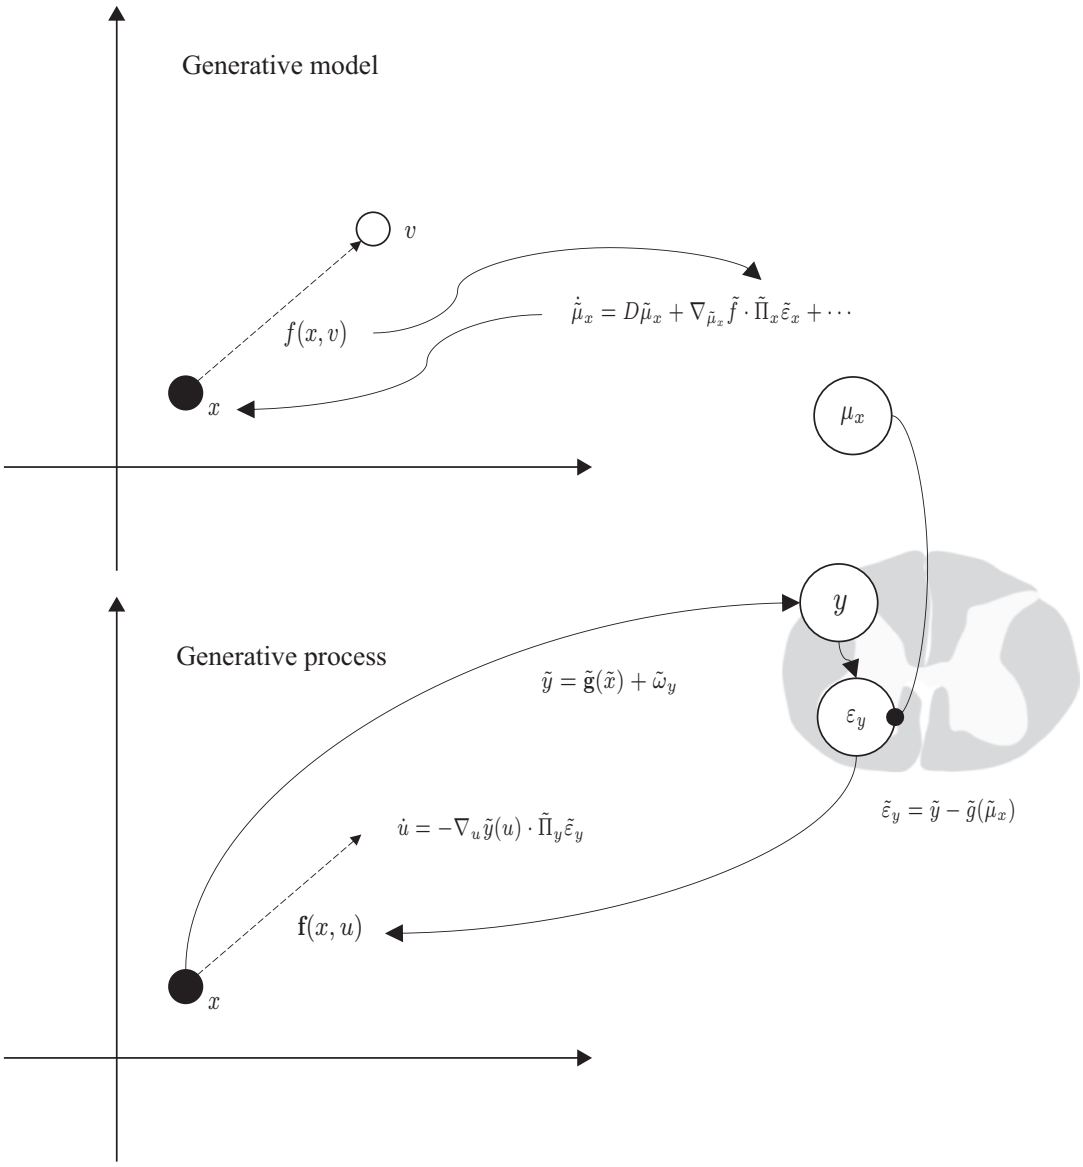


图 8.1: 脊髓反射，说明产生行动时，外部世界中的生成过程与生成模型的区别. 模型假定肢体、手或其他身体部位的位置 x 被拉向某点 v，上图虚线箭头表示此信念. 以关于 x 的信念 μ_x 替代 x，可更新关于其变化率的信念，再通过模型的 g 函数预测感觉数据 y. 实际感觉数据则由生成过程的 g 生成，以真实 x 为自变量. 误差 ε_y 驱动行动 u 改变以消除误差. 原图注把这说成通过 “生成模型” 解决，但接着说明行动通过 $\mathbf{f}$ 决定真实 x 的变化率，使 x 到达产生与预测 $g(\mu_x)$ 一致数据的位置，并令 ε_y 及行动变化率为零；该过程/模型措辞疑点保留于问题记录. 图内 Generative model：生成模型；Generative process：生成过程. 译者绘图说明：相空间轨迹、坐标轴、数学节点、更新式文字及连接按源坐标以原生 TikZ 路径和 LaTeX 文字重建，仅脊髓解剖背景保留图像；图中公式并另录于下.

框 8.1：精确度、注意与感觉衰减

第 7 章已讨论精确度的重要性，但值得回顾其在连续时间系统中的作用. 在许多方面，此处更自然，因为 Π 变量直接来自 Laplace 近似. 在推断动力学中，它直接作为乘性增益，见图 8.1；不同精确度对信念更新的不同影响赋权.

把精确度解释为突触增益，使它与神经生物学的几个重要方面相联系. 经验上，精确度较高意味着更强的信念更新；电生理研究中可能表现为峰值较早、幅度较大的诱发反应，单细胞记录中则可能表现为，对位于该细胞感受野内刺激的放电率有乘性效应. 这些发现常与注意加工相关，即某个感觉通道或通道子集优先于其他通道. 主动推断视角下，精确度与注意是同义语. 精确度已用于在计算机中再现多种注意现象，包括 Posner 范式（Feldman and Friston 2010）. 具体地，用线索预测两个位置之一的感觉输入精确度，可再现经验发现：有线索位置的刺激反应快于另一位置.

精确度控制的第二个重要方面，是在运动产生中的作用. 想象没有这种控制时会发生什么. 如果以高精确度预测感觉数据，那么数据所传递的消息就获得高突触增益，导致对某身体部位位置的真实推断. 问题在于，主动推断把运动指令等同于预测. 准确的 “我没有在动” 信念，无法预测运动的感觉后果，而这种预测对启动运动至关重要. 高精确度感觉输入下，“我在动” 的信念会立即被相反证据纠正，于是没有运动. 因而要产生运动，必须能够忽略其感觉后果，形成最初为假的 “我在动” 信念. 一旦此信念建立，就能预测运动的本体感受及其他感觉后果，并通过图 8.1 的机制实施. 忽略相反证据的过程称为感觉衰减，表示运动发生所需的精确度下降（Brown, Adams et al. 2013；Pezzulo 2013；Seth 2013；Pezzulo, Rigoli, and Friston 2015；Seth and Friston 2016；Allen et al. 2019）.

框 8.1（续）

显然，在运动之间恢复精确度很有用，可从感觉输入中作适当推断. 这意味着衰减与运动交替的循环，例如眼跳期间周期性抑制视觉输入，随后抑制眼跳. 把运动建立在注意暂时悬置之上，与 19 世纪用于解释催眠诱发运动的观念运动理论密切相关.

Lotka–Volterra 动力学来自生态学中捕食者—猎物动力学的刻画. 虽然它已用于许多学科，捕食者—猎物系统仍能给出运作直觉. 捕食者种群小时，猎物可以增加，形成较大种群，为捕食者提供更多食物，随后捕食者种群增加. 捕食增强使猎物减少，进而使捕食者减少，循环由此继续. 产生的振荡模式中，猎物种群先达峰值，然后是捕食者，再是猎物，依此类推. 推广到两个以上种群，例如肉食动物、食草动物、植物，可以生成一列峰. 图 8.2 展示三种群的广义 Lotka–Volterra 动力学：

$$f(x, v) = x \circ (v + Ax). \tag{8.6}$$

这里 x 仍是向量，$\circ$ 表示逐元素乘积. 内禀出生率和死亡率由 v 给出；A 是矩阵，原文规定：若列标种群捕食行标种群，元素为正；关系倒转则为负.[12]

图 8.2 清楚表明，纳入 Lotka–Volterra 动力学的生成模型，可依据当前哪个峰最高进行时间排序（Huerta and Rabinovich 2004）. 各曲线可视为表示隐状态，而非物

[12]译注：依本式通常的 A_{ij} 作用于第 i 种群的约定，这一捕食关系符号叙述存在疑点；按源保留，不据生物直觉调换符号.

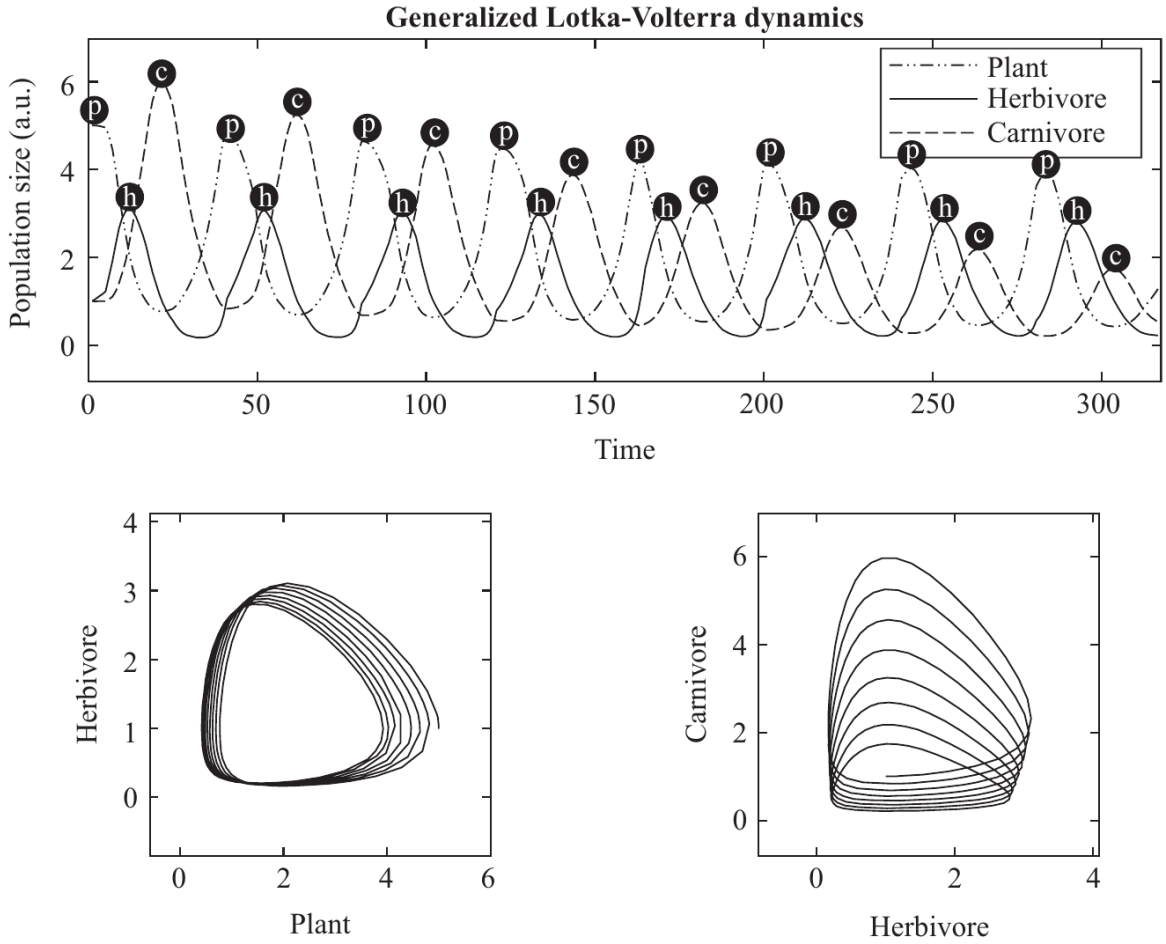


图 8.2: Lotka–Volterra 系统涌现的广义序列动力学，与第 7 章假定的离散序列动力学形成重要连接. 此动力学可用于多种系统，这里为易解释而采用捕食者—猎物关系. 上：种群随时间变化，大小用任意单位 a.u. 表示；各峰按当时种群最大的物种标记. 重复的 p、h、c 模式可看作三个不必等间隔的离散时间步序列. 下：轨迹突出各自近似周期的模式. 图内 Generalized Lotka-Volterra dynamics：广义 Lotka–Volterra 动力学；Population size：种群大小；Time：时间；Plant/p：植物；Herbivore/h：食草动物；Carnivore/c：肉食动物.

种. 图 8.3 突出两个用此动力学生成行为的重要例子. 一个层级模型用 Lotka–Volterra 系统提供的序列动力学，确定相对于条件刺激的眨眼反应时刻（Friston and Herreros 2016）. 该范式基于研究小脑功能的范式：朝动物眼睛吹气的无条件刺激诱发眨眼，听觉音调这样的条件刺激则可多次在吹气前呈现. 学习条件刺激和无条件刺激之间有多少个 Lotka–Volterra 动力学峰，见框 8.2，使动物学会预先应对气流，在适当时刻眨眼. 这是一种时间学习，因为峰的数量隐式估计两种刺激间的时间间隔. 第二个例子中，各序列峰关联不同吸引点，驱动运动依次到达排列成类似手写轨迹的一系列吸引点（Friston, Mattout, and Kilner 2011）. 两例表明，广义 Lotka–Volterra 系统为利用连续动力系统建立序列动力学模型提供了有用方法.

框 8.2：连续模型中的学习

如第 7 章所述，学习优化关于生成模型参数 θ 的信念. 连续时间中，这意味着随时间积累证据，仿佛把一系列无穷小时间间隔中的数据视为独立同分布，并构建由时间不变参数生成观测的模型：

$$\begin{aligned}\ln p(\tilde{y},\theta) &= \ln p(\theta) + \int \ln p(y(t)\mid\theta)\,dt \\ &\approx \ln p(\theta) - \int F[y(t)\mid\theta]\,dt.\end{aligned}$$

可用它构建泛函 S，通过以参数为条件的自由能的时间积分，发挥参数自由能的作用. 使用 Laplace 近似，得到以下形式，其中 α 积累自由能梯度，即证据梯度：

$$\begin{aligned}S(\theta) &= \mathbb{E}_{q(\theta)}\left[\ln q(\theta) + \int F[y(t)\mid\theta]\,dt - \ln p(\theta)\right] \\ &\approx \int F[y(t)\mid\mu_\theta]\,dt - \ln p(\mu_\theta), \\ \dot{\mu}_\theta &= \partial_{\mu_\theta} S(\mu_\theta) \\ &= \partial_{\mu_\theta}\ln p(\mu_\theta) - \int \partial_{\mu_\theta} F[y(t)\mid\mu_\theta]\,dt \\ &= \partial_{\mu_\theta}\ln p(\mu_\theta) - \alpha, \\ \dot{\alpha} &= \partial_{\mu_\theta} F[y(t)\mid\mu_\theta].\end{aligned}$$

译注：原式写 $\dot{\mu}_\theta = +\partial_{\mu_\theta} S$，下一行却是由上述 S 得到的负梯度形式；符号冲突照源保留，未静默改为下降式. 独立同分布和连续时间积分的形式处理也依作者原有说明，不另加未证明的严格极限解释.

在主动推断应用中，第 7 章的 POMDP 形式已大体取代广义 Lotka–Volterra 系统. 但记住这种动力学仍然有用：它是一种可能支持离散序列动力学的合理连续系统. 此外，Lotka–Volterra 系统明确区分了深度时间规划中的序列表示，与运动广义坐标中的变化率表示，见第 4 章；二者各有用途，但处理不同问题.

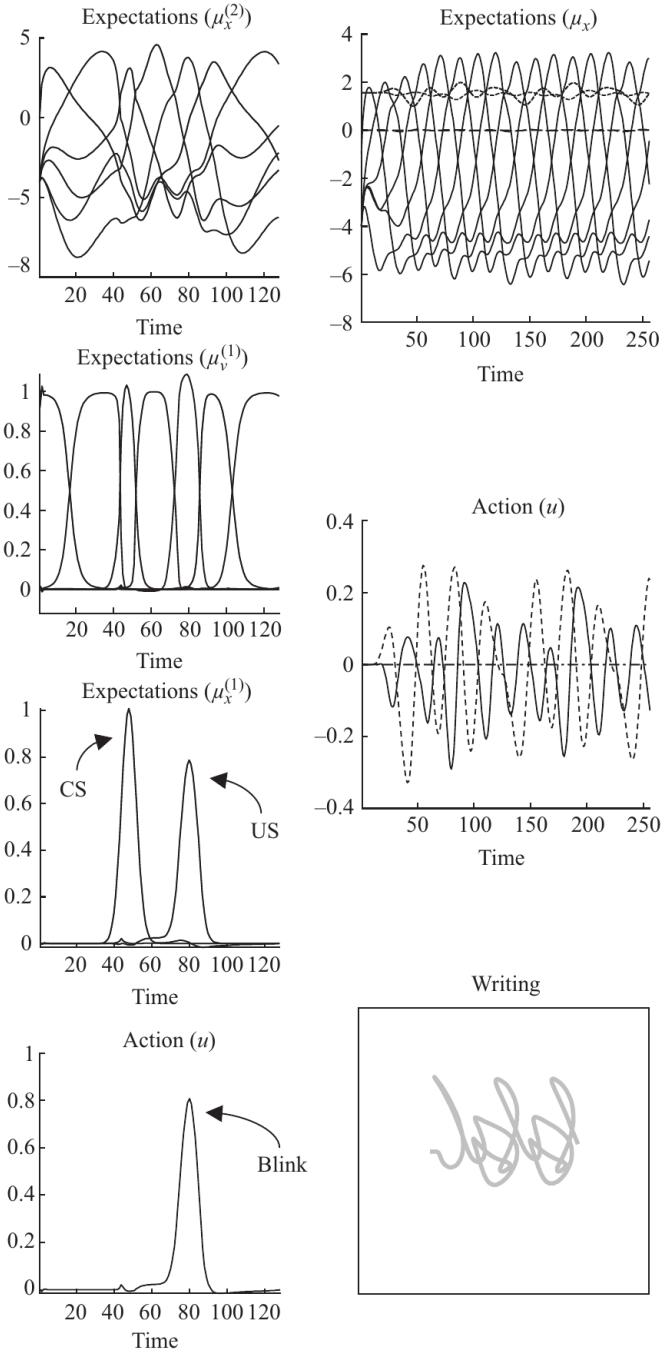


图 8.3: 广义序列 Lotka–Volterra 动力学在主动推断中的两项应用. 左：用于经验研究小脑功能的眨眼条件化（Friston and Herreros 2016）. 从最高层开始，期望状态具有图 8.2 的序列模式；向下一层传递，预测序列隐成因. 这里各峰再预测下一层状态，其中首峰为条件刺激 CS，次峰为无条件刺激 US. 最后，预测 US 诱发眨眼行动. 右：采用式 (8.5) 的吸引点，但根据 Lotka–Volterra 系统当前哪个种群最高来选择具体吸引子，于是依次访问各点，产生类似手写的形式（Friston, Mattout, and Kilner 2011）. 图内 Expectations：期望；Action：行动；Time：时间；Blink：眨眼；Writing：书写.

另一类在主动推断研究中广泛应用的动力系统是 Lorenz 系统：

$$\dot{x} = \begin{bmatrix} \sigma(x_2 - x_1) \\ x_1(\rho - x_3) - x_2 \\ x_1 x_2 - \beta x_3 \end{bmatrix}. \tag{8.7}$$

参数分别称为 Prandtl 数 σ、Rayleigh 数 ρ 和与系统物理性质有关的常数 β. 参数取值不同，系统行为可能很不一样. Lorenz 吸引子最初用于描述大气对流动力学，其游走行为促使研究者将它纳入生成模型，模拟富有挑战的推断问题. 一个重要例子是鸟鸣模拟，下一节将展开. 这些系统也用于模拟简单物理系统，研究在什么条件下其行为开始显得具有感知性. 图 8.4 展示示例参数设置下 Lorenz 系统的行为.

8.4 广义同步

如上所述，连续状态空间模型的一项关键应用，是基于合成鸟鸣的一系列研究（Friston and Frith 2015b），其中一个重要方面涉及交流与多智能体推断. 思想基础是：生物能够使内部状态与世界中的某物同步，即推断. 当外部对象是另一个具有相似模型的生物时，同步意味着二者的内部状态应逐渐相似，是一种原初的心智理论.

图 8.5 展示模拟鸣禽所用生成模型的类型. 此层级模型中，高层、第二层状态按缓慢的 Lorenz 系统演化，其一个维度用于参数化低层、第一层较快 Lorenz 系统的 Rayleigh 数. 低层变量再映射到感觉声谱数据. 类似图 8.1，生成过程还包含行动；这里行动影响喉部，而非移动肢体，使鸟能影响声谱数据. 行动仍由消除预测误差而生成. 若鸟听到了自己预测的歌声，就不必亲自发声；若预测歌声却未听到，就必须开始鸣唱来消除误差.

图 8.5 的模型公式（译者排版补充）

$$f^{(2)} = \frac{1}{128}\begin{bmatrix} 10(x_2^{(2)} - x_1^{(2)}) \\ (32 - x_3^{(2)})x_1^{(2)} - x_2^{(2)} \\ x_1^{(2)} x_2^{(2)} - \frac{8}{3}x_3^{(2)} \end{bmatrix}, \qquad g^{(2)} = x_1^{(2)},$$

$$f^{(1)} = \frac{1}{16}\begin{bmatrix} 10(x_2^{(1)} - x_1^{(1)}) \\ \theta((v_1^{(1)} - 8) - x_3^{(1)})x_1^{(1)} - x_2^{(1)} \\ x_1^{(1)} x_2^{(1)} - \frac{8}{3}x_3^{(1)} \end{bmatrix}, \qquad g^{(1)} = \begin{bmatrix} x_2^{(1)} \\ x_3^{(1)} \end{bmatrix}.$$

当有两只生成模型结构相似的鸟时，动力学更有趣. 一只鸣唱时，另一只不必鸣唱，因为没有误差要消除；但一只停止时，另一只须继续同一首歌. 这产生一种轮流行为，有时称为“照同一张歌谱唱歌”，各自贡献同一首歌的片段. 为什么轮流，而非一只始终向同类唱完整首歌？答案与框 8.1 的感觉衰减有关：通过行动生成鸟鸣，需要降低关于行动后果预测的精确度. 类似眼跳运动，这意味着在注意感觉数据（视觉或听觉），与改变数据的行动（眼跳或发声）期间的感觉衰减之间交替. 两个智能体时，就产生倾听对方与自身鸣唱的交替，即简单的对话.

要使合成对话奏效，两只鸟必须相互同步，并知道自己处于歌曲或对话轨迹何处，即生成模型中关于隐状态的推断应相互一致. 图 8.5 右上是尚未针对彼此优化生成模型

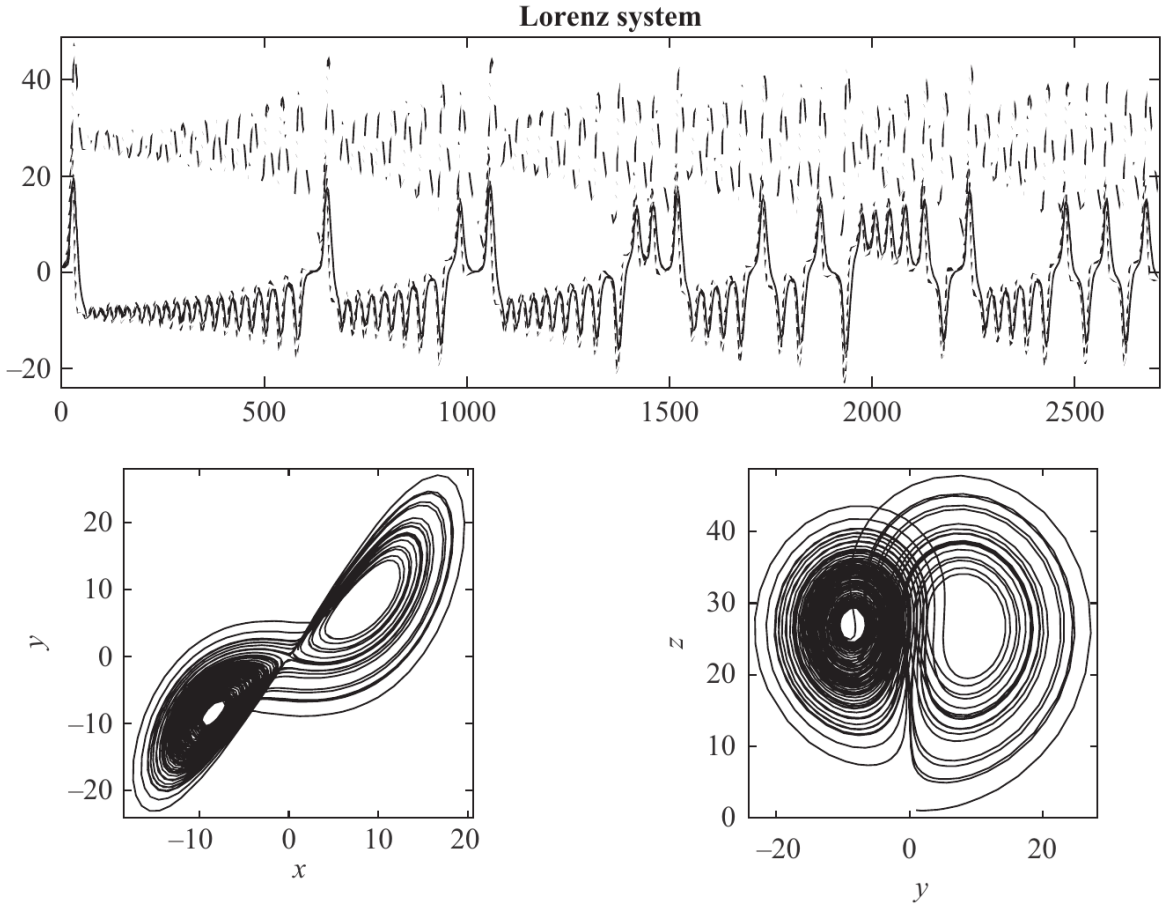


图 8.4: Lorenz 系统吸引子的行为，采用与图 8.2 相同的格式，展示三维系统如何演化. 典型特点是显得混沌而不可预测：在空间某一部分绕行一段时间，再切换到另一轨道. 这种游走性与表面自主性，使该系统适合纳入生物现象模型. 图内 Lorenz system：Lorenz 系统.

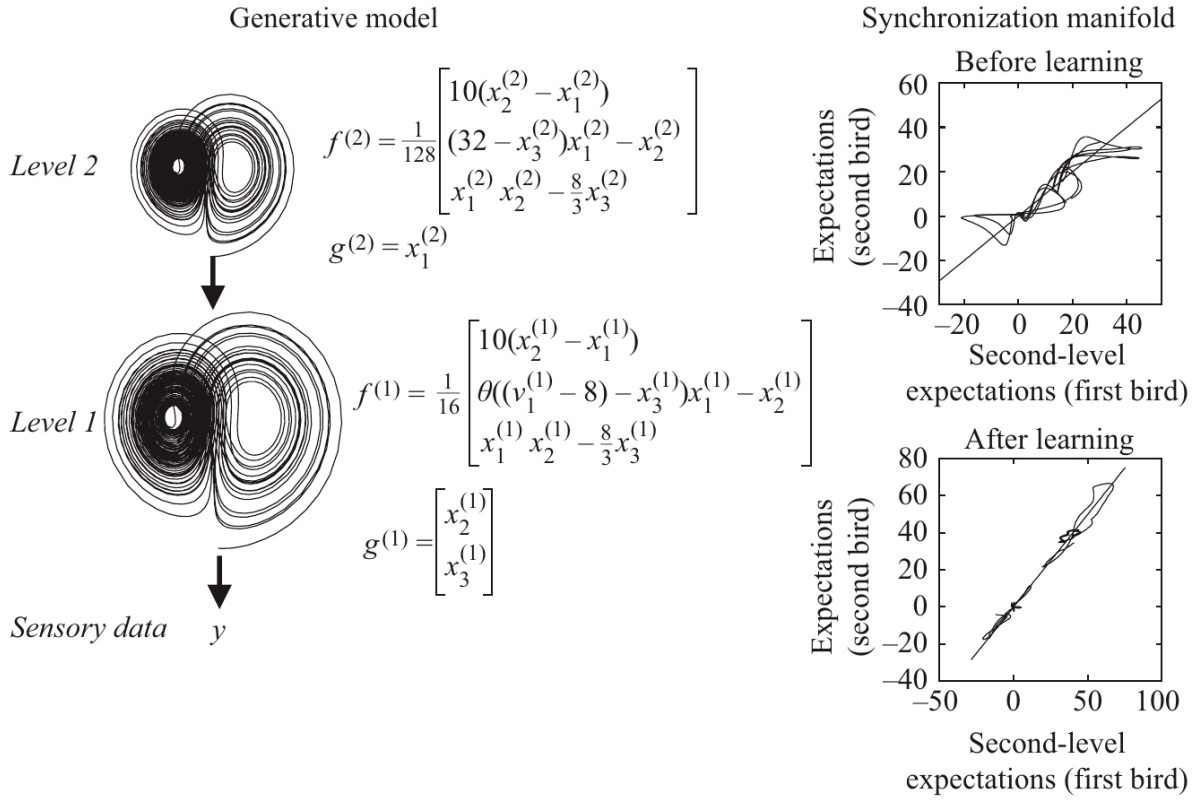


图 8.5: 同步与交流. 左: 支持正文鸟鸣模拟的层级生成模型, 每层含 Lorenz 吸引子. 右: 两只鸟在相互学习前后, 第二层期望的同步流形. 学习彼此生成模型的参数后, 两只鸟的联合轨迹局限在几乎一维的子空间中, 表示同步. 图内 Generative model: 生成模型; Level 2/1: 第二/一层; Sensory data: 感觉数据; Synchronization manifold: 同步流形; Before/After learning: 学习前/后; Second-level expectations (first bird): 第一只鸟的第二层期望; Expectations (second bird): 第二只鸟的期望. 译者排版说明: 原图的吸引子相图与同步轨迹忠实裁切, 数学表达式另录于下, 避免把图中公式仅存为位图.

的两只鸟的同步流形，画出各自对高层隐状态所持信念的轨迹. 同步意味着，一只推断某隐状态值时，另一只也应推断相同值，因此预期轨迹固定于 $x = y$ 直线；技术上称为混沌的完全同步. 图中直线周围的涨落表示同步不完美. 相互接触并学习彼此模型参数后，见框 8.2，右下图的同步近乎完美. 这意味着各鸟都了解了对方，能够推断对方脑中发生什么；它们学会共享同一叙事，照同一张歌谱唱歌.

更一般的同步不要求沿 $x = y$ 直线. 在广义同步中，联合行为占据比可供其占据的二维空间更低的一维空间；但这个低维空间，即同步流形，可能弯曲或具有其他形状. 类似地，我们处在行星表面的二维空间中，尽管表面弯曲成三维球面. 除了社会行为中的核心作用，广义同步，即占据高维联合空间的低维区域，对把生物系统刻画为从事推断的系统也很重要：这是内部与外部状态的广义同步. 本书无篇幅展开这一广阔主题，但推断视角涉及与自闭症等神经精神综合征相关的广义同步失效. 此类同步不只对连续时间模型重要，也对多个智能体之间语言交流的 POMDP 模型重要（Friston, Parr et al. 2020）.

8.5 混合的离散与连续模型

本章与前章表明，离散与连续模型在主动推断中各有重要应用. 许多情境只需其一，但更整体的视角承认二者很可能同时存在. 因而需要一种方法，组合生成模型，使单个模型同时含连续与离散变量（Friston, Parr, and de Vries 2017）. 这种混杂或混合模型，允许推断序列行动计划，再通过连续模型把决定转成运动. 图 8.6 展示其形式：高层是依第 7 章方式运行的 POMDP，在每个离散时间步生成本章这类连续模型，把连续时间分解为一串短连续轨迹.

要从离散层的结果转到连续层，须把各备选结果与连续空间中的点关联. 考虑灵长类研究常用的延迟期眼动任务，见图 8.7. 它有三个阶段：首先，猴保持注视中央十字，目标出现在例如四个可能位置之一；接着目标消失，须在延迟期间记住它；最后给出眼跳信号，猴须看向原目标出现的位置. 完成任务需要推断序列，即当前处于哪一阶段，以及应瞄准四个位置中的哪一个. 这些范畴推断问题适合 POMDP. 但选定位置后，猴必须实施眼动，把中央凹移到目标位置的连续坐标.

图 8.7 展示解决此问题的混合生成模型. 上图中，模型高层进行范畴决策，计算四个时段内四个离散目标位置的后验信念；中图与下图中，低层计算高层离散推断产生的连续行为轨迹，即眼动. 从离散目标位置决定转成连续眼动，要求每个离散目标位置 o 都关联一个连续隐成因 v 的分布，以标识目标坐标. 随后，通过对这些位置作贝叶斯模型平均，并以 POMDP 层的推断赋权，就能计算目标坐标的先验：

$$
\begin{aligned}
P(\tilde{v} \mid o_\tau) &= \mathcal{N}(\tilde{\eta}_{o_\tau}, \tilde{\Pi}_v), \\
P(\tilde{v}) &\approx \mathcal{N}(\tilde{\boldsymbol{\eta}}, \tilde{\Pi}_v), \\
\tilde{\boldsymbol{\eta}} &= \mathbb{E}_{Q(o_\tau)}[\tilde{\eta}] = \mathbf{o}_\tau \cdot \tilde{\eta}.
\end{aligned} \tag{8.8}
$$

要推断哪个离散目标最好地解释连续数据，必须计算各假设目标的证据；它是观测到的连续数据的函数. 这体现混合模型需要高低层的相互作用. 图 8.7 表明，这既促进关于应在何处进行眼跳的信念形成，也促进适时执行眼跳.

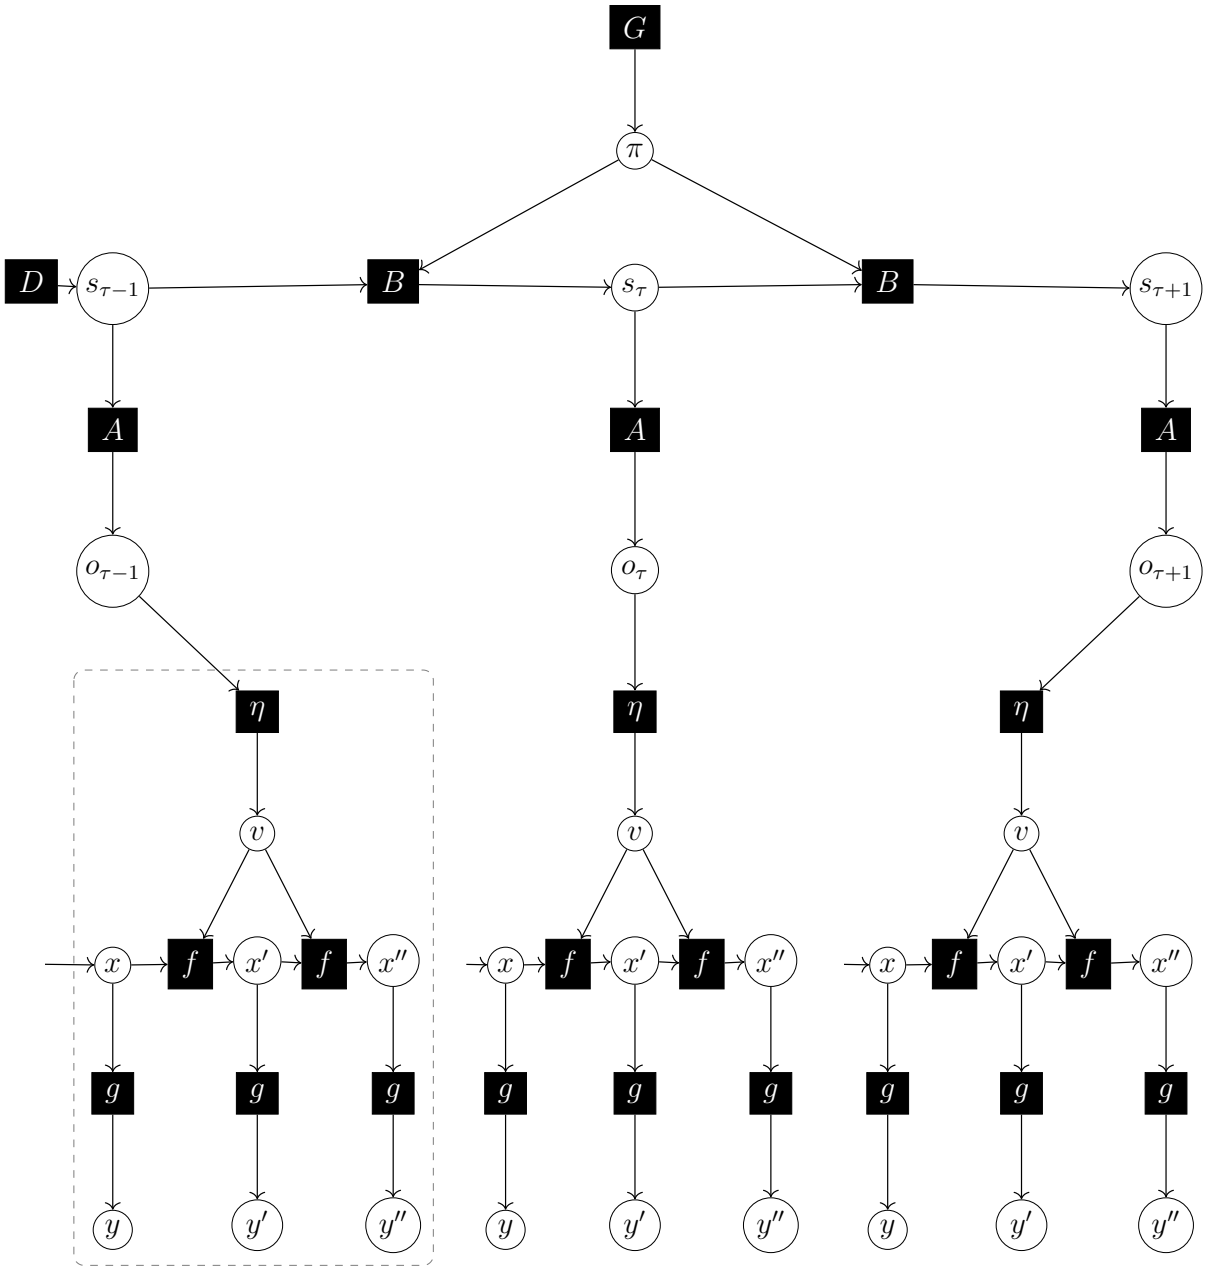


图 8.6: 混合生成模型的层级形式，类似图 7.12，但高低层模型的形式有重要区别. 低层（原图以虚线框标出最左一个实例）为本章的连续状态、连续时间模型，采用运动广义坐标. 高层则为第 7 章的离散状态、离散时间 POMDP. 实际上，这使我们能以规则时间间隔，在连续轨迹的备选片段之间选择. 图用 tikzcd 重建；虚线框恢复原图对最左低层实例的标示，保留各连续轨迹的入边.

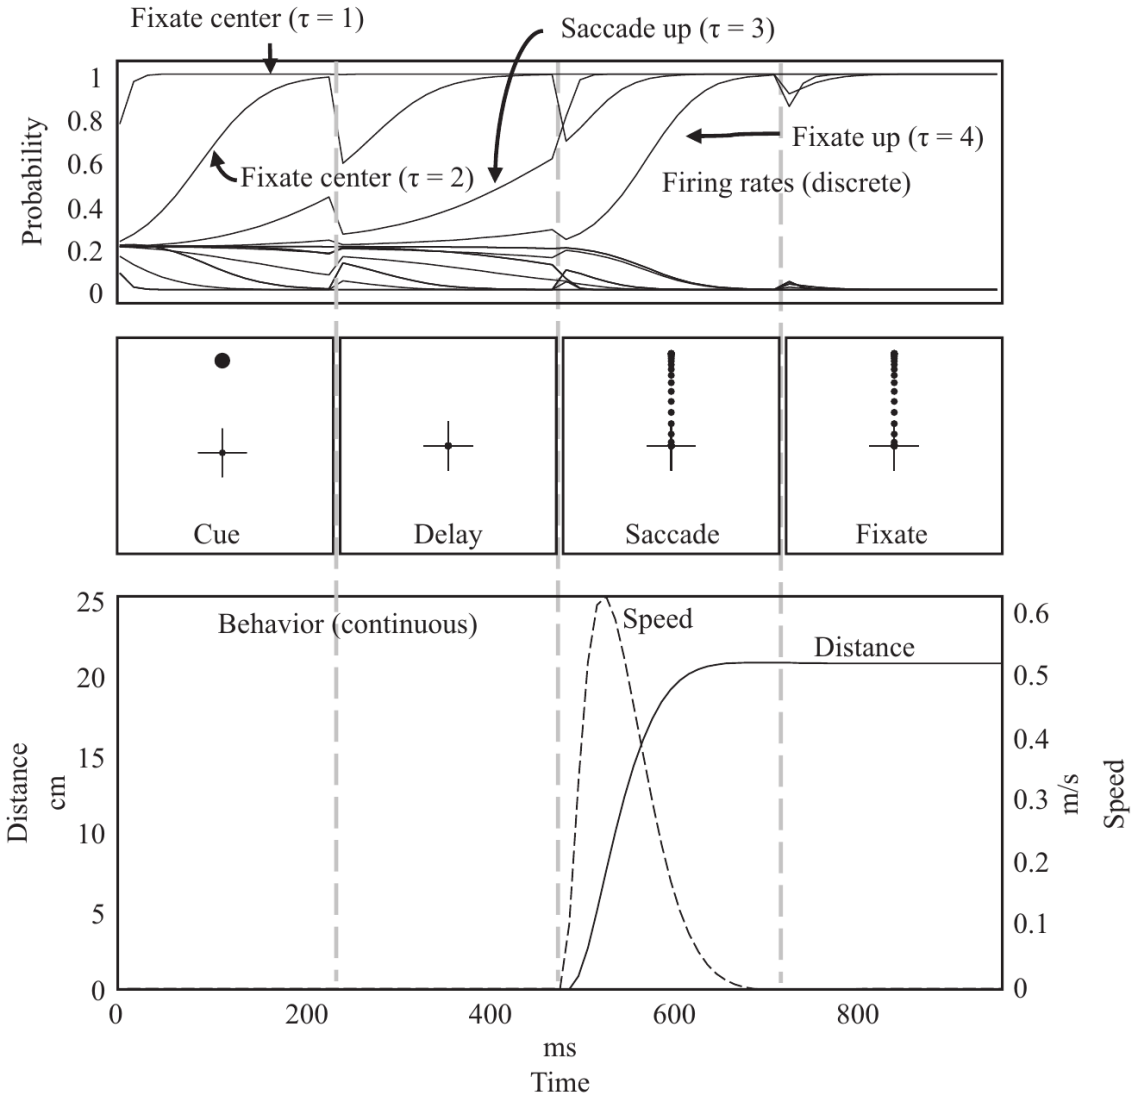


图 8.7: 用混合或混杂模型把决策转成运动（Parr and Friston 2019b），采用正文的延迟期眼动范式. 上：表示目标位置后验信念的神经元放电率. 目标有四个位置，合成实验有四个时间步，因而 16 个神经种群表示各组合；最终推断状态所对应曲线已标注. 注意目标初现的第一步 0–250 ms，以及智能体观测自己向该处眼跳的第三步 500–750 ms 的信念更新. 中：从中央到目标位置的眼跳行为. 实验首四分之一，目标在上方可见；接着在延迟期维持注视，随后眼跳到正确位置，最后维持目标注视. 下：上图离散推断产生的连续行为轨迹. 图内 Fixate center/up：注视中央/上方；Saccade up：向上眼跳；Probability：概率；Firing rates (discrete)：放电率（离散）；Cue/Delay/Saccade/Fixate：线索/延迟/眼跳/注视；Behavior (continuous)：行为（连续）；Distance/cm：距离/厘米；Speed/m/s：速度/米每秒；Time/ms：时间/毫秒.

框 8.3：混合模型与聚类

在主动推断之外，组合范畴与连续生成模型的问题，主要从聚类角度表述：把每个连续数据点分配到某个离散簇. 虽然已有多种算法解决，但大多隐含依赖类似这里的生成模型，即高斯的混合，也称高斯混合模型：

$$
\begin{aligned}
P(\tilde{y}, \tilde{s}, D, \eta, \Pi) &= P(D)P(\eta)P(\Pi)\prod_i P(s_i \mid D)P(y_i \mid s_i, \eta, \Pi), \\
P(D) &= \mathrm{Dir}(d), \\
P(s_i \mid D) &= \mathrm{Cat}(D), \\
P(y_i \mid s_i, \eta, \Pi) &= \mathcal{N}(\eta_{s_i}, \Pi_{s_i}).
\end{aligned}
$$

聚类方法要推断各簇的均值 η、精确度 Π，以及各数据点 y_i 属于某簇的后验概率 $P(s_i \mid y_i)$. 对第 8.5 节的目的，我们假定 η、Π 的先验十分精确，为 delta 函数，并通过贝叶斯模型约简计算 $Q(s_i) \approx P(s_i \mid y_i)$，见框 7.3.

第一个离散时间步，即连续尺度上至 250 ms，猴能有一定确信地推断：第一步眼睛注视中央十字，第二步、至 500 ms 会维持注视，之后最可能的行动路线会使中央凹对准上方位置. 这可见于上图离散放电率. 它转成连续行为；行为实施后，提高了对离散状态的信念置信度. 注意第三步 500–750 ms 连续数据可用后，向上眼跳的概率增加. 这一基于实验认知研究的简单例子，展示离散行动计划与连续实施之间相互转换的基本原理.

8.6 小结

本章概述主动推断中连续时间生成模型的应用. 这是巨大主题，很多内容未涉及，进一步阅读见表 8.1. 但上述总体概念为进一步探索提供基础. 我们具体把运动产生视为预测的实现，大幅简化运动控制问题，因为不需额外装置或逆模型，只需脊髓或脑干反射弧. 我们突出了此类运动控制中精确度与感觉衰减的作用. 连续方案的一项关键优点，是用动力系统表述生成模型，因此我们概述了主动推断研究中广泛应用的两类常见动力系统：广义 Lotka–Volterra 系统在连续情境中提供时间排序，Lorenz 吸引子则可生成丰富模拟，包括合成鸟鸣. 接着讨论广义同步：系统内部状态与外部状态同步，构成用推断解释脑功能的基础；对社会系统尤其关键，因为其外部状态很大部分是同类，即像我一样的生物. 最后统一第 7、8 章的离散与连续模型，把 POMDP 的期望自由能最小化动力学（利用与探索）、这些动力学要求的行为之连续实施，以及介导二者相互作用的双向消息传递结合起来. 简言之，从决策走向运动，再由运动回到决策.

表 8.1: 连续时间模型的关键进展

应用	来源	说明
合成鸟鸣	Friston and Frith 2015a; Friston and Frith 2015b; Isomura, Parr, and Friston 2019	研究合成智能体之间的交流与互动：模拟一对或一群互相鸣唱的鸣禽，展开从广义同步、知觉推断到感觉衰减的现象.
眼动延迟	Perrinet, Adams, and Friston 2014	利用运动广义坐标模型中隐含的近过去、近未来信念，通过略向未来或过去投射，解释感觉运动延迟.
条件反射	Friston and Herreros 2016	用 Lotka–Volterra 系统模型学习条件与无条件刺激的时间关系，产生预期性眨眼.
平滑追踪眼动	Adams, Perrinet, and Friston 2012	研究追随视觉目标的平滑追踪眼动，旨在再现神经典型者与精神分裂症个体，在有、无视觉遮挡的追踪反应中的差异.
精神病	Adams, Stephan et al. 2013	基于鸣禽和平滑追踪模型，研究错误的精神病性推断如何由次优先验信念产生.
错觉	Brown and Friston 2012; Brown, Adams et al. 2013	错觉有助揭示感觉输入不确定或模糊时，大脑采用的先验信念. 这些论文用若干常见错觉例子，展示特定先验信念下错觉推断的最优性.
眼跳	Friston, Adams et al. 2012; Donnarumma et al. 2017; Parr and Friston 2018a	类似平滑追踪模拟，研究眼动控制，但眼睛不是简单跟随目标，而须移到多个可能目标位置之一. 研究所需生成模型，以及模型指定后涌现的架构和生理活动.
行动观察	Friston, Mattout, and Kilner 2011	研究镜像神经元系统，形式化这样的思想：自身行动的生成模型，也能用于建模并复制观察到的他人行为.
注意	Feldman and Friston 2010; Kanai et al. 2015	预测精确度即隐式选择我们认为最有信息的数据. 实现此思想可再现 Posner 范式和图形—背景辨别任务中的经典心理物理发现.
混杂模型	Friston, Parr, and de Vries 2017; Parr and Friston 2018c; Parr and Friston 2019b	将离散 POMDP 与预测编码方案结合. 现有例子大多涉及视觉搜索或眼动控制，需要选择看哪里，再实施看向那里.
自组织	Friston 2013; Friston, Levin et al. 2015; Palacios et al. 2020	若各细胞具有关于某结构相同的隐式生成模型，细胞群可组织成预定义结构. 具体地，它们须知道：若自己是某类细胞，应预测何种感觉输入.

Chapter 9

基于模型的数据分析

有了最好的锤子，并不意味着每个问题都是钉子.
——Barack Obama

9.1 引言

本书所述模型归根结底只有在能够回答科学问题时才有用. 本章关注如何运用主动推断理解经验数据. 核心思想是：作为科学家，我们可以诉诸前面各章假定大脑使用的同一套数学. 总体目标是恢复被试大脑用于产生行为的生成模型，即主观模型，的参数. 为此，可以使用我们自己的生成模型，即关于主观模型如何产生行为的客观模型. 根据观察到的行为反演客观模型，就能推断主观生成模型的参数. 这种元贝叶斯推断为我们提供机会，检验关于大脑所用模型的假设，并依据个体必须持有何种先验信念，其行为才是贝叶斯最优的，来刻画个体表型. 这种基于信念的计算表型分析，在正在兴起的计算精神病学、神经心理学和神经病学领域具有应用前景.

9.2 元贝叶斯方法

本章讨论主动推断形式在行为实验数据分析中的用途. 这超出了前几章的原理验证模拟，而是用主动推断回答科学问题. 我们已经看到，主动推断下，被试的生成模型是行为的关键决定因素. 因而，关于经验行为测量之成因的假设，必须表述为选择这些行动所用的备选生成模型. 挑战在于：操纵生成模型的参数，即先验信念，把主动推断方案拟合到观测数据.

概括而言，把计算模型拟合到观察到的行为，有两个相互联系的目的. 第一，估计模型中关注的参数，找出最能解释特定被试或被试组行为的值. 这有助于从产生行为的计算来刻画主观行为，称为计算表型分析（Montague et al. 2012；Schwartenbeck and Friston 2016；Friston 2017）. 计算表型可以与其他测量结合，例如建立神经成像发现与功能之间的联系；也可以单独用于预测其他情境中的行为，例如治疗干预后的行为.

第二，比较用模型表达、对某种行为现象给出不同解释的备选假设（Mirza et al. 2018）. 参数估计与模型比较这两项目标，对应贝叶斯定理的一侧：参数估计是在模型下，求某个参数配置的后验概率；模型比较则依赖各模型的边缘似然，即证据. 回顾贝叶斯定理：

$$\underbrace{P(u \mid \theta, m)}_{\text{似然}} \underbrace{P(\theta \mid m)}_{\text{先验}} = \underbrace{P(\theta \mid u, m)}_{\text{后验}} \underbrace{P(u \mid m)}_{\text{证据}}. \tag{9.1}$$

右侧是模型 m 下，给定行为数据 u 后参数 θ 的后验概率，以及模型证据；左侧说明需要为模型指定什么：所关注参数的先验信念和一个似然函数.

虽然我们使用与前面各章相同的贝叶斯推断方案，这里的目的却不同，因为存在两个推断过程，见图 9.1. 第一，生物用关于其感觉数据生成过程的模型，推断世界以及如何行动；这一直是前面各章的重点. 第二，作为客观科学家，我们观察生物的行为，通过反演自己的客观生成模型，推断它所用的主观生成模型. 这意味着我们在对一个推断过程进行推断，有时称为 “元贝叶斯” 推断（Daunizeau et al. 2010）.

更形式化地说，这一方法用主动推断问题的解来定义似然分布. 采用给定参数配置，可以模拟主动推断下的行为，量化采取一系列行动的似然. 再配以这些参数值的先验信念，就得到关于生物如何用其生成模型产生行动的生成模型. 尽管这里关注主动推断，特别是离散时间模型，通用方法可以用于任意似然函数. 其他规范性行为模型，例如强化学习中所用的模型，可以替代主动推断模型.

以下各节展开可用于元贝叶斯推断的一种通用推断方案，即变分 Laplace，以及用于模型比较的层级模型. 然后给出基于模型的数据分析的简单步骤，最后回顾一个关键实例. 有效运用这些方法不必掌握技术细节；不感兴趣的读者可跳过第 9.3、9.4 节.

基本思想是：给定未知的关注参数，即被试先验信念的参数，计算任意一组观察到的选择的似然. 然后以通常方式，把此似然与这些参数的客观先验结合，计算关于被试先验的后验. 若有多个被试，可用参数经验贝叶斯，简称 PEB，结合各后验，推断群体或被试间效应. 所需似然就是在被试的行动后验信念下，采样到所观察选择序列的概率. 此后验信念依赖被试看到了什么，即线索或刺激，以及其先验信念；求解适当主动推断方案即可直接计算. 我们使用了两次贝叶斯程序：先求被试的行动后验信念，再求我们对刻画该被试之未知先验的后验信念. 下面逐一介绍这套元贝叶斯程序的各部分.

9.3 变分 Laplace

变分 Laplace 是一种与预测编码基于相同原理的推断方案（Friston, Mattout et al. 2007），但可以用于比此前高斯似然更一般的似然函数. 先概述这里关注的似然函数 $\mathcal{L}(\theta)$：它应给出生成模型参数取 θ 时，主动推断方案中行动的概率. 所选行动依赖已经作出的观测：

$$\begin{aligned}
\mathcal{L}(\theta) &= \ln P(\tilde{u} \mid \theta, m, \tilde{o}),\\
P(\tilde{u} \mid \theta, m, \tilde{o}) &= \tilde{u} \cdot \sigma(\theta_\alpha \ln \tilde{\mathbf{u}}),\\
\tilde{\mathbf{u}} &= \boldsymbol{\pi} \cdot U,\\
\boldsymbol{\pi} &= \arg\min_{\boldsymbol{\pi}} F.
\end{aligned} \tag{9.2}$$

第一行给出实际实验中观察到的行动序列 $\tilde{u}$ 的对数似然，它是参数 θ、模型 m 和所呈现刺激序列 $\tilde{o}$ 的函数. 用参数设定第 7 章那类 POMDP 的先验信念，就能求这些行动的概率. 随后按第 4、7 章求解 POMDP，强制模拟采用实际观察到的行动序列，并呈现相同实验刺激. 这涉及计算合成被试对于所选策略或行动路线的信念 $\boldsymbol{\pi}$，使其世界生成模型的自由能 F 最小. 随后由这些信念计算执行某行动序列的平均概率：把每个策略的概率分配到该策略蕴含的行动上，行动由数组 U 索引. 最后施加 softmax 温度参数 θ_α，计及模型未解释的行为随机性，即 “手抖”. 若该参数为 1，就等于假定被试从其行动后验信念采样行动，有时称为匹配行为. 若参数很大，发出的行动则是主观后验最大

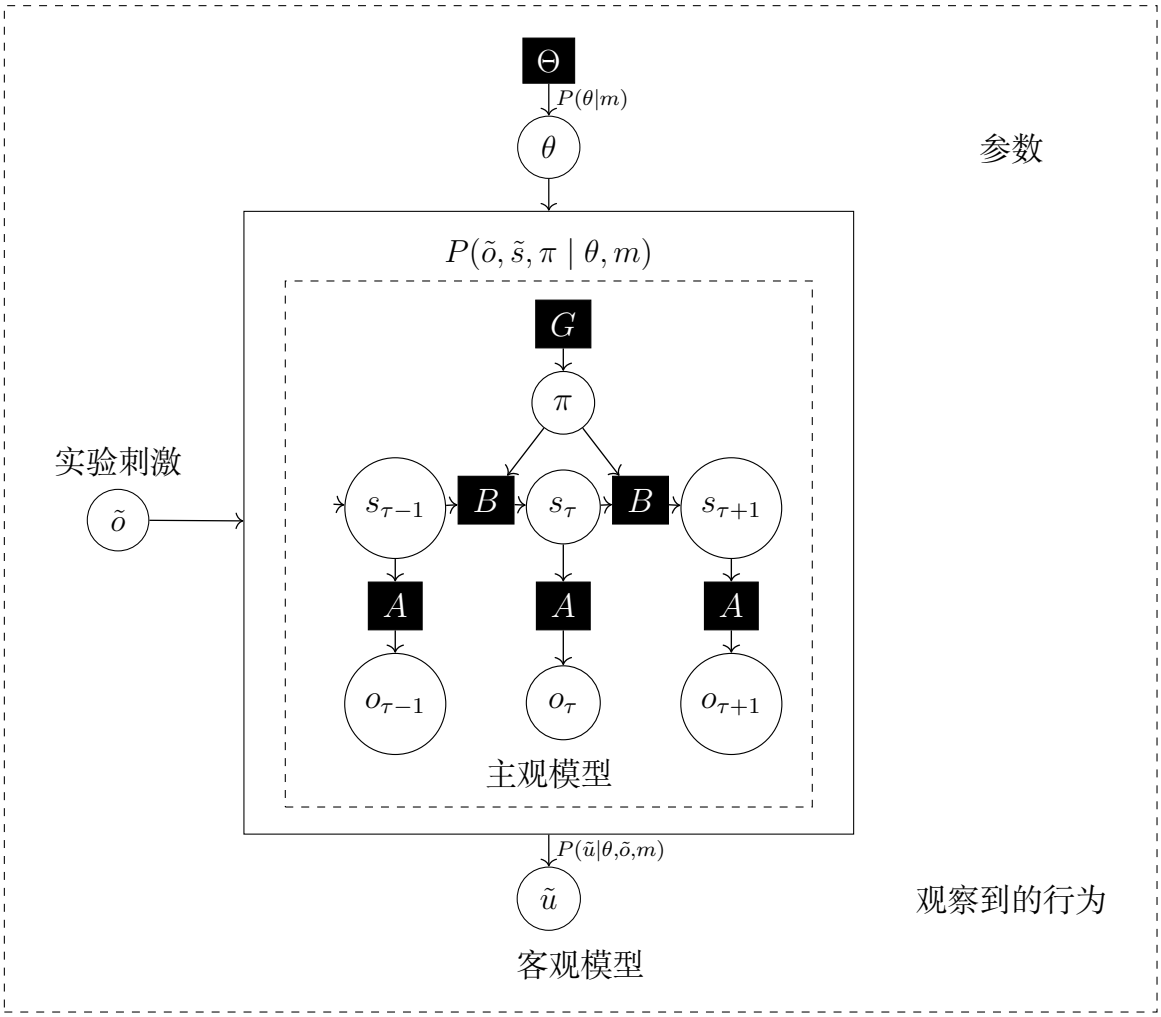


图 9.1: 元贝叶斯推断中主观模型与客观模型的关系. 内虚线框：假定实验被试使用的主观模型，可以是图示 POMDP，也可以是其他模型；重要的是，它依赖未知值的参数 θ，并生成感觉数据 o. 外虚线框：实验者的客观模型 m 包含参数先验信念，预测呈现实验刺激后预期出现的行为 u；刺激从主观模型角度就是感觉数据. 客观模型的似然分布依赖主观模型：先把参数纳入主观模型，再用前章主动推断方案求解，把实验刺激作为感觉数据呈现，推断最可能行动路线的分布；最后计算该分布下实际行动或选择的概率. 这就是给定参数和刺激后观察行为的似然，即客观模型的似然分布. 图以原生 tikzcd 重建.

的行动，即总选择最可能选项. 此 softmax 参数本身也可以估计.[13]

结果是在给定刺激序列和参数时，模型下行动的概率，即给定模型后行为数据的似然. 为客观参数配上高斯先验[1]，$\theta \sim \mathcal{N}(\eta, \Pi^{(1)})$，便可用 Laplace 假设表达模型证据的自由能近似：

$$\begin{aligned} \ln P(\tilde{u} \mid m, \tilde{o}) &\approx \mathcal{L}(\mu) + \frac{1}{2}\left(\varepsilon \cdot \Pi^{(1)}\varepsilon + \ln\left|\nabla_{\mu\mu}\mathcal{L}(\mu) - \Pi^{(1)}\right|\right), \\ \varepsilon &= \eta - \mu, \\ \mu &= \arg\max_{\mu}\left\{\mathcal{L}(\mu) - \frac{1}{2}\left(\varepsilon \cdot \Pi^{(1)}\varepsilon + \ln\left|\nabla_{\mu\mu}\mathcal{L}(\mu) - \Pi^{(1)}\right|\right)\right\}. \end{aligned} \tag{9.3}$$

译注：本式首行括号前为加号，末行目标中为减号，按源 PDF178 书页、物理 189 页原样保留. 此处没有据通常 Laplace 证据式静默调换符号，省略的归一化常数与行列式所需条件亦须结合原约定审校.

式 (9.3) 与框 4.3 展开的式子相同，只是推广到多维参数空间，代入后验协方差的显式形式，并假定正态先验. 第 4 章及第 8 章应用中，忽略了不依赖众数的项；但在模型比较问题中，必须包括它们.

为找到使式 (9.3) 最后一行最大化的 μ，进行梯度上升. 二次假设下，它化为

$$\dot{\mu} = \nabla_{\mu}\mathcal{L}(\mu) + \Pi^{(1)}\varepsilon. \tag{9.4}$$

这里所用对数似然的梯度可能没有显式形式，但可以用有限差分[2]得到合理数值近似，也可求出后验精确度，即负对数似然的二阶导数或 Hessian 加上先验精确度. 式 (9.4) 是最简单更新形式，实际常用基于局部曲率的更精细方法.

9.4 参数经验贝叶斯（PEB）

上一节的变分 Laplace 程序，让我们能够推断选择行为的模型并量化其证据，从而刻画个体计算表型，比较关于该个体的备选假设. 然而，有趣的问题常在群体层面：例如先验偏好精确度这样的参数如何随年龄变化？可先用第 9.3 节的方法，为不同年龄参与者逐人拟合行为模型，再构建把年龄考虑在内、生成关注参数的一般线性模型：

$$P(\theta \mid \beta, X) = \mathcal{N}(X\beta, \Pi^{(2)}). \tag{9.5}$$

X 的各列为不同解释变量，各行为不同参与者. 首列通常全为 1，表示跨被试平均参数的效应；本例第二列可为各参与者的年龄. 向量 β 表示 X 各解释变量的效应大小. 第一个分量就是精确度或其他参数的平均值，第二个分量是年龄对精确度的效应，即横轴年龄、纵轴预测精确度图中直线的斜率. X 可以有任意多列，β 相应有任意多个分量.[14]

拟合式 (9.5) 的模型并为 β 配先验后，就能询问解释变量的作用. 例如，比较允许 β 第二个分量偏离 0 的模型，与精确信任该分量为 0 的模型的证据，就能询问年龄是否影响先验偏好精确度. 实践中，可用贝叶斯模型约简而不必反复反演模型（Friston, Parr, and Zeidman 2018）.

[13]译注：原文称其为温度参数，但按所写 $\sigma(\theta_{\alpha}\ln\tilde{\mathbf{u}})$，增大参数使分布更集中，作用与通常的逆温度一致. 原公式和名称均保留；序列的点积及概率聚合沿用作者的压缩记号，未另行假定独立性补成乘积.

[14]译注：若年龄列未中心化，线性模型截距一般不是样本平均精确度；源文对第一个分量的平均值解释隐含了相应设计约定，照源保留并说明.

9.5 基于模型的分析步骤

实际用主动推断分析经验选择行为时，遵循以下步骤（Schwartenbeck and Friston 2016）. 其中提到 SPM12 Matlab 包中的相关例程.

1. 收集行为数据，包括所作选择，以及选择者可获得的感觉输入. 还要收集二级被试间分析所需数据，例如是否为患者或对照，以及相关人口学信息等.

2. 按第 7 章构建 POMDP 模型. 它应是一个以参数为输入、输出完整指定但尚未求解之 POMDP 的函数.

3. 指定似然函数，即式 (9.2)，说明如何用模型计算似然. 通常调用 POMDP 求解器，例如 `spm_MDP_VB_X.m`，模拟行为并量化观察行动的似然.

4. 用期望和精确度指定参数先验信念，往往以 0 为中心，精确度反映合理取值范围.

5. 求解后验概率与模型证据，使用上述变分 Laplace 等标准推断方案，见式 (9.4). `spm_nlsi_Newton.m` 例程可自动完成.

6. 进行群体层面分析，通常使用 PEB，把各个体的估计参数当作二级模型生成的量，从而检验这些参数成因的假设. 实践中可用 `spm_dcm_peb.m`. 其他分析包括标准统计检验，考察各被试推断参数与其特有测量的关联；例如用典型变量分析考察问卷分数与推断参数的关系.

图 9.2 以第 7 章 T 形迷宫任务中大鼠的行为，概括这些步骤. 先将大鼠置于 T 形迷宫，左右臂之一有奖赏刺激，中央臂有信息线索，再记录行动序列. 可跨多次试验重复，记录学习行为；也可对不同大鼠、不同干预，例如药理或光遗传干预，重复.

获得行为数据后，需要似然函数，量化特定参数配置下，给定大鼠在给定条件中的行为概率. 可以用第 7 章的 POMDP 模型实现，模型须以我们要求似然的参数来参数化. 例如评估偏好精确度时，可加入一个对数尺度参数，使偏好分布更尖或更平.

从大鼠角度设置生成模型后，可用第 4 章的信念更新式自动求解 POMDP，从而在偏好尺度参数取特定值时，计算模型下数据，即访问迷宫臂序列，的条件概率. 将此似然与先验结合，就从科学家角度完整指定了行为生成模型. 通过变分 Laplace 求解，可为每只大鼠得到尺度参数的后验概率分布.

实践中，分析真实数据之前，可先用 POMDP 产生虚拟数据，考察在当前问题下是否定性合理，从而检查其表面效度. 另一个合理检验是参数恢复：在已知参数配置下产生虚拟数据，再反演模型，观察能否恢复这些参数. 这有助于验证某些参数或其组合是否可恢复，即是否可辨识.

最后，可为线性模型构建设计矩阵，各行代表一个计算表型，例如各被试偏好的后验密度，各列为被试的不同属性，即可能解释大鼠偏好差异的变量. 除了代表所有大鼠平均偏好的全 1 列，还包括年龄、是否给药等. 有了被试间效应模型，便可进行 PEB 分析，评估这些解释变量对先验偏好的贡献.

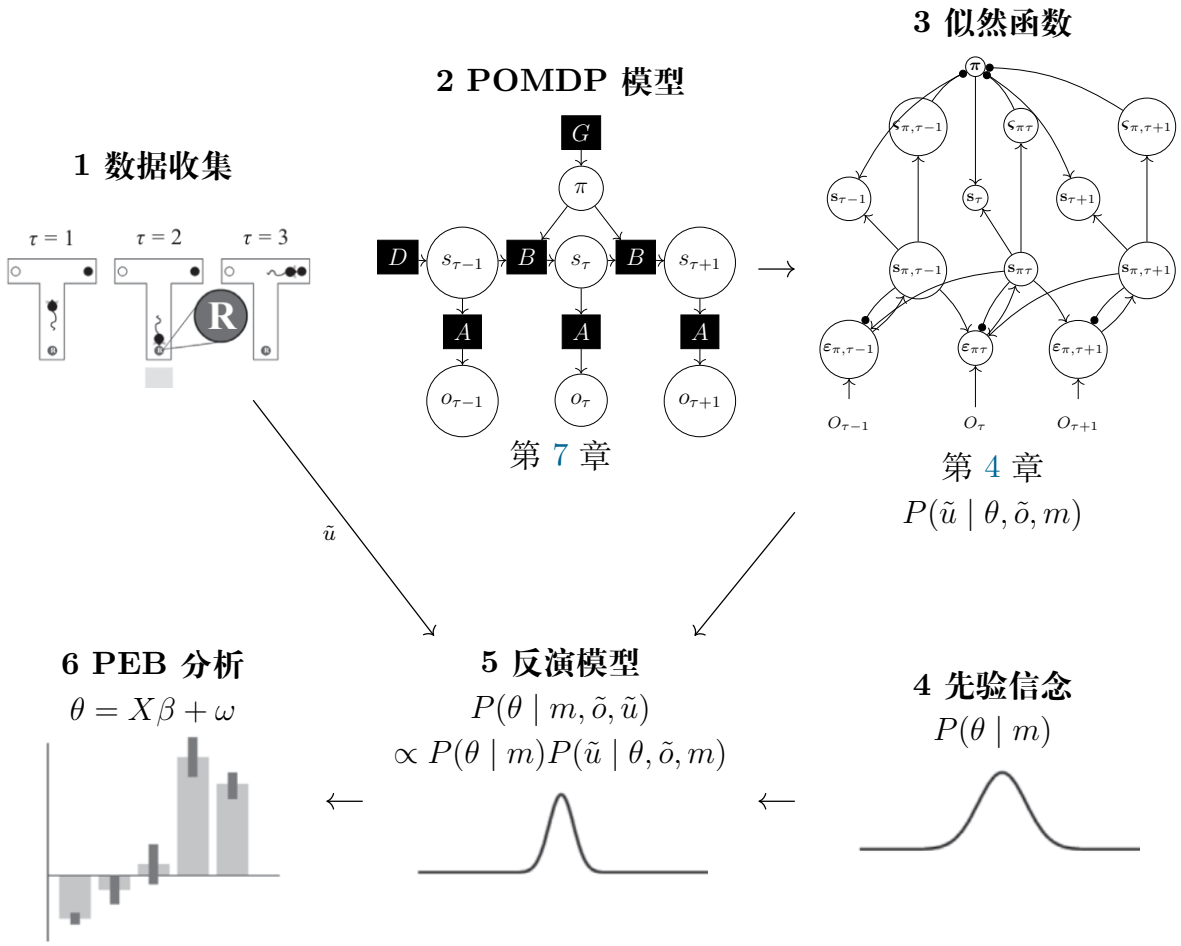


图 9.2: 正文所述基于模型数据分析的六步反演路线图，并标出进一步细节所在章节. 箭头表示依赖关系：须先定义 POMDP，才可计算似然；模型反演需要收集的数据、似然和先验；须先对各被试反演模型，才能进行 PEB 分析. 第 4、5 步示意模型下参数分布从先验到后验的更新. 各模型的证据与后验随后可结合于 PEB，求得预测这些参数的线性模型中 β 系数的后验密度，以期望及可信区间表示. 外层依赖、POMDP 及第 3 步神经消息图均用 tikzcd 重建，保留神经消息图的错列节点、曲线连接与圆点末端；先验/后验密度和组效应曲线忠实裁自源示意图.

9.6 生成模型的实例

本节利用文献中的两个实例，说明连续和离散生成模型的运用. 先简述 Adams, Aponte et al.（2015）与 Adams, Bauer et al.（2016），本节下称 Adams 等，为平滑追踪眼动建模、量化各被试生成模型精确度参数的方法. 其设计的重要方面是同时通过脑磁图收集电生理数据，使作者能够研究精确度或确信编码的神经生物学基础. 再讨论 Mirza et al.（2018），本节下称 Mirza 等，用 POMDP 表述的眼跳分析. 图 9.3 示意两项实验；希望这些实例能帮助读者理解，如何用上述通用方法经验性地回答科学问题.

按图 9.2 的顺序，Adams 等收集被试注视运动视觉目标时的数据，第 1 步. 细节并不重要，但任务有两个条件：第一，目标按可预测正弦曲线运动；第二，在同一轨迹上加入高斯噪声. 收集的数据包括眼动轨迹. 作者构建主观模型，第 2 步；与图示 POMDP 不同，选择了第 8 章那类连续模型. 简言之，模型预测眼睛的本体感受和视觉输入，假定注视点受目标位置吸引. 似然，第 3 步，以第 4 章的主动预测编码方案构建，量化给定一组对数精确度参数及第 2 步模型下，行动即眼动的概率.

第 4 步，作者把对数精确度先验设为正态分布；第 5 步，反演模型，求这些精确度参数的后验分布. 第 6 步没有用 PEB，而是使用行为任务同步收集的神经成像数据：通过动态因果建模估计初级视觉皮层浅层锥体细胞的增益. 于是每个被试都有精确度与突触增益估计，可以评估主观模型参数与其生物学基础的相关，进行群体层面分析. 此相关的展示，是运用行为主动推断形式提出并回答信念更新与神经生物学关系问题的重要例子.

第二个例子中，Mirza 等用主动推断 POMDP 研究信息增益驱动人类行为的作用. 按六步展开：第 1 步，在被试执行视觉觅食任务时收集行为数据，任务是将视觉场景归入若干类别之一. 只有注视某位置，该处场景元素才显露，因此须多次注视，才能为某场景类别取得足够证据. 作者记录了眼跳，即快速眼动的序列. 第 2 步，采用 Mirza et al.（2016）所述 POMDP，以当前注视位置及场景类别为条件，预测离散化本体感受、视觉及反馈结果. 对反馈结果赋予偏好，使模型预期并偏好正确分类，见第 7 章. 第 3 步，在不同参数配置下，以第 4 章方案求解模型，得到似然；参数包括偏好分布精确度的对数尺度参数等. 第 4 步，为对数尺度及其他参数指定先验；第 5 步，逐被试反演模型. 作者利用各被试的估计对数证据，评估含或不含期望自由能认知成分的行为驱动模型，发现所有被试中，包含认知可供性的模型证据都更高. 第 6 步，用 PEB 评估多次试验过程中被试先验信念的变化，发现支持信念参数变化，即主动学习，的证据. 最后使用典型协变量分析，考察各被试估计表型变量的线性组合，例如偏好精确度，与表现指标的线性组合，例如正确率和反应时，之间的关系.

9.7 错误推断的模型

人通常很快便相信自己希望成真的事.
——Julius Caesar

鉴于这些方法与计算精神病学等领域的关系（Friston, Stephan et al. 2014），最后概述错误推断：把精神病理学理解为信念更新失效时，它居于核心位置. 主动推断这样的推断框架的好处之一，是同时处理精神障碍的多个维度，将不适应行为，例如强迫或成瘾，

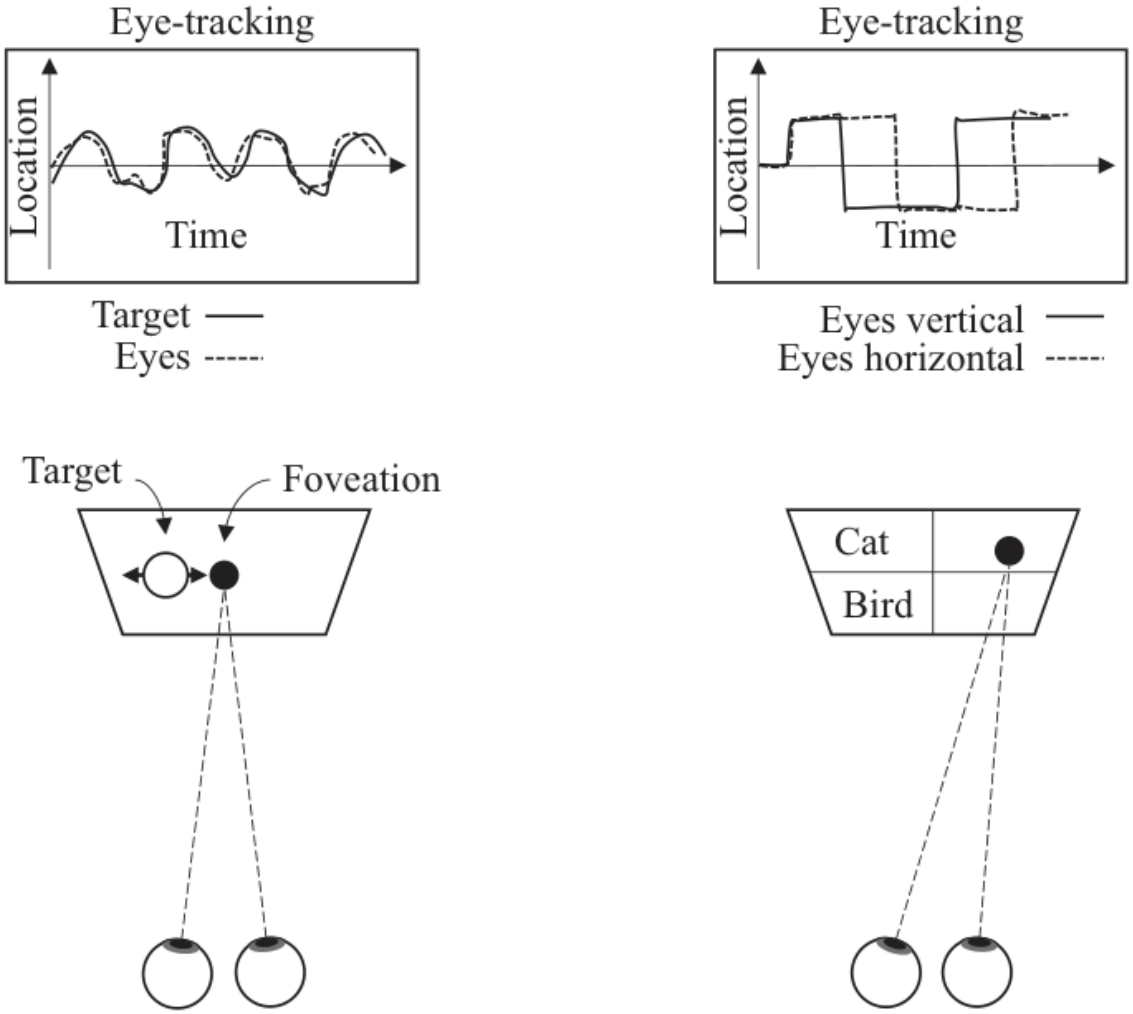


图 9.3: 正文两个实验. 源图注指向原 9.5 节，实例实际位于第 9.6 节；保留这一源指向疑点. 细节并不重要，图突出元贝叶斯推断已被成功运用的场景和行为数据类型. 左: Adams 等测量被试追踪运动目标时的平滑追踪眼动. 右: Mirza 等测量探索任务中的眼跳；视觉显示分为四象限，其中两象限有刺激，即猫和鸟. 不同场景类别有不同刺激配置，因此参与者须选择注视哪些象限，以获得足够信息分类场景. 左侧产生连续眼动追踪数据，右侧产生可离散化的注视序列，均是图 9.2 第 1 步的行为数据 u. 图内 Eye-tracking: 眼动追踪；Location: 位置；Time: 时间；Target: 目标；Eyes: 眼睛；Foveation: 中央凹注视；Eyes vertical/horizontal: 眼睛垂直/水平位置；Cat/Bird: 猫/鸟.

与心理层面现象，例如错误信念，以及生物层面现象，例如神经调质异常，联系起来.

这里无法充分介绍用主动推断建模疾病过程的广泛文献，只给出极简概述，提示思考计算病理的框架. 表 9.1 是非穷尽的说明性实例，包括分别基于第 7、8 章模型、在离散与连续时间中指定的模型. 以下诉诸 POMDP 类模型的结构，这些情境中支撑错误推断的原理大体相同.

推断方法，包括主动推断，背后的假设是：精神病理状态可以概念化为推断障碍. “障碍” 不必意味着推断机制有缺陷，例如产生不正确后验概率. 表 9.1 多数研究中，推断机制正常运作，却基于有缺陷的生成模型，即具有异常先验信念的生成模型. 因而最终病理是异常先验信念的后果；可以用本章基于模型的数据分析恢复这些先验.[15]

表 9.1: 主动推断中的计算病理

病理	来源	说明
成瘾、冲动与强迫	FitzGerald, Schwartenbeck et al. 2015；Schwartenbeck, FitzGerald, Mathys, Dolan, Wurst et al. 2015；Mirza et al. 2019；Fradkin et al. 2020	成瘾是行为看似异常、却能在适当生成模型下表述为最优推断的重要例子. Schwartenbeck 等用有限报价任务说明：参与者对继续等待是否得到奖赏有不同确信，低确信导致与成瘾相关的强迫行为. 后续用离开斑块范式研究冲动程度对应的先验信念，并研究先验精确度衰减在强迫症中的作用.
妄想	Brown et al. 2013；Friston, Parr et al. 2020	妄想以固定的错误信念为特征，在主动推断中可表述为缺乏支持证据时的精确后验概率分布；若足够精确，即使随后出现矛盾证据也保持固定. 各妄想机制可能不同，例如感觉衰减失效可能对能动性妄想至关重要. 近期工作给出共享妄想、二联性精神病的例子：两个没有信息的智能体，对世界状态达成确信的共识.
幻觉	Adams, Stephan et al. 2013；Benrimoh et al. 2018；Parr, Benrimoh et al. 2018；Corlett et al. 2019	模拟基于先验与似然精确度失衡. 似然精确度未能衰减，导致过度解释伪感觉数据；或过度衰减，导致未能纠正先验信念；二者都为错误知觉推断提供机制.

[15]译注：本段陈述作者所述建模假设及研究解释，不等于所有精神疾病已被证明由异常先验引起，亦不保证任意实验都能唯一辨识所需先验；本章已要求参数恢复检验.

表 9.1（续）

病理	来源	说明
人际与人格障碍	Moutoussis et al. 2014；Prosser et al. 2018	人际推断依赖关于他人及其如何回应自己决策的模型，促成了涉及两方或多方互动的信任游戏与慈善游戏模型. 后者用于再现精神病态中的自我夸大与无悔意，方法是调节自我价值信念在多大程度上依赖慈善或自私决策，以及对他人认可的敏感性.
眼动综合征	Adams, Perrinet, and Friston 2012；Parr and Friston 2018a	连续时间生成模型预测牛顿系统的动态演化；令生成模型的某些方面与其他方面条件独立，可诱发核间性眼肌麻痹等眼动综合征.
药物治疗	Parr and Friston 2019b	按第 5 章提出的精确度参数与神经化学物质联系，应能模拟药理操纵的后果. 此工作说明数种合成药理干预对眼动延迟期任务表现的后果，提供原理验证：这些方法不仅可模拟病理，也可模拟治疗作用.
前额叶综合征	Parr, Rikhye et al. 2019	模拟区分内侧与外侧前额叶综合征：衰减转移精确度，损害记忆引导任务的执行，对应外侧；衰减决定任务参与动机的内感受似然精确度，对应内侧.
视觉忽略	Parr and Friston 2017a	数种受损先验都可引起对左侧空间的不注意. 例如增大该侧 Dirichlet 参数，降低向左眼跳的新奇性，从而更多采样右侧. 也可设置偏好右侧本体感受或视觉结果，或增加习惯性向右眼跳，产生定性相似行为.
内感受推断障碍	Barrett et al. 2016；Allen et al. 2019；Maisto, Barca et al. 2019；Pezzulo, Maisto et al. 2019；Barca and Pezzulo 2020；Tschantz et al. 2021	内感受推断模拟提示，例如关于心脏或胃信号的先验与似然精确度失衡，可引起关于身体内部状态的错误信念、对躯体症状的错误知觉，以及心身性幻觉；还可级联影响自主神经调节与行动选择，引起过度警觉、过量用药、过度限制食物等不适应行为.

异常先验可以关于状态、精确度，也可以是关于生成模型形式的结构先验. 思考病理行为成因的一种有用方式，是考察策略先验信念及各部分如何被破坏，产生异常策略选择. 策略先验依赖期望自由能，后者又依赖后验信念、信息增益潜力和先验偏好 C；

还可为策略先验加上表示习惯偏差的固定形式项 E.

逐一考察：后验信念依赖先验与似然，异常后验须由其一或两者受扰产生，典型形式是低估或高估精确度的平衡. 似然精确度相对先验过高，导致过度解释可能含噪的感觉输入，即从伪数据得出无根据结论的过拟合. 若反方向失衡，偏重对先验的确信，内部生成的知觉便抵抗相冲突的感觉输入. 两种机制都被联系到幻觉形成；层级模型中可以共存. 考虑到各种精确度与神经调质化学物质的关联，见第 5 章，胆碱能信号受损的路易体痴呆，以及多巴胺系统异常的精神分裂症等出现幻觉，即错误知觉推断，似乎是合理的.

再看信息增益：似然精确度说明不确定性可消除到什么程度，先验信念精确度说明尚有多少不确定性可消除. 先验信念精确度可以作用于生成模型参数，影响新奇性；也可以作用于状态，影响显著性. 将条件概率参数解释为突触效能，将精确度解释为突触增益，就提示突触断联综合征可以看作其中之一或两者受扰. 缺失的突触无法调节，就像对条件概率具有极其确信的先验，新数据不能更新相应效能. 这对不同策略潜在信息增益有重要意义，已用于感觉忽略综合征建模.

最后，偏好与策略先验明确影响行为，可能支撑成瘾习惯，或多种精神与神经综合征中的淡漠（Hezemans, Wolpe, and Rowe 2020）. 总之，上述生成模型不同位置的缺陷先验，为病理行为提供功能性或目的论解释.

9.8 小结

本章概述用前章理论模型向经验数据提出问题的方法，让我们以主动推断作为非侵入工具，探查个体作决策所用的计算过程. 这里只聚焦少数简单实例，但已有主动推断模型用于更真实、更复杂的任务（Cullen et al. 2018），诱发更丰富行为，进行计算表型分析. 除了六步分析程序，还突出两个实例，展示程序中的关键变化：测量的是平滑轨迹还是离散选择，模型选连续还是离散，以及提出何种科学问题. 最后一项最重要，因为它决定前两项选择. 我们看到计算表型与神经成像结合，用于询问突触增益与精确度的关系（Adams, Bauer et al. 2016）；也看到模型反演如何评估备选行为驱动因素及表现预测因素的贡献（Mirza et al. 2018）. 最终，这六步为设计实验、非侵入地探查人或其他动物用来驱动行为的隐式生成模型，提供通用方法，有机会回答神经系统健康与疾病状态下的功能问题.[16]

[16]译注：源小结末句把六步指向图 9.1，但实际六步路线图为图 9.2；图 9.1 说明主观与客观模型.

Chapter 10

主动推断：有感知行为的统一理论

一般说来，心智最擅长做的事，恰是我们最少意识到的事.
——Marvin Minsky

10.1 引言

本章收束主动推断的主要理论要点，即本书第一部分，以及实际实现，即第二部分. 随后把各点连接起来：从前面各章的具体主动推断模型中抽象出来，关注框架的整合方面. 主动推断的一项优点，是为有感知生物必须解决的适应问题提供完整解法，因而对知觉、行动选择、注意、情绪调节等问题提供统一视角. 心理学与神经科学通常孤立处理这些问题，人工智能也采用不同计算方法. 我们将结合控制论、观念运动行动理论、强化学习、最优控制等既有理论，逐一讨论主动推断对这些问题及其他问题的看法. 最后简述如何扩展主动推断范围，涵盖本书未深入讨论的其他生物、社会和技术主题.

10.2 回顾

本书系统介绍了主动推断的理论基础和实际实现. 这里简要概括前九章，借此复习本章余下部分所需的关键构造.

第 1 章把主动推断引入为一种规范性方法，用来理解作为环境行动—知觉环路一部分的有感知生物（Fuster 2004）. 规范性方法从第一原理出发，推导并检验有关现象的经验预测；这里的现象，是活体如何在与环境进行适应性交换，即行动—知觉环路，的同时持续存在. 我们还考虑了通往主动推断的低路与高路.

第 2 章说明低路：从大脑是具有生成模型的预测机器这一思想出发. 生成模型以概率方式表示世界隐因如何生成感觉，例如苹果反射的光如何刺激视网膜. 反演模型，就推断感觉成因，例如给定视网膜受某种刺激，推断是否看到了苹果. 这种知觉即推断的观点，历史根源是 Helmholtz 的无意识推断，近来则是贝叶斯脑假说. 主动推断进一步把行动控制与规划纳入推断，即控制即推断、规划即推断. 尤其是，它说明知觉与行动在本质上并非可分离过程，而是服务同一目标. 我们先非形式化地把该目标描述为最小化自身模型与世界的差异，通常归结为惊异或预测误差最小化. 简言之，可通过改变心智以适应世界，即知觉，或改变世界以适应模型，即行动，使二者差异最小. 这些过程可用贝叶斯推断描述，但精确推断常不可处理，所以主动推断采用变分近似；精确推断也可看作近似推断的特例. 于是得到第二种更形式化描述：知觉与行动共同最小化变分自由能. 这是主动推断的核心量，可分解为能量与熵、复杂度与准确度，或惊异与散度

等. 最后引入第二种自由能，即期望自由能. 它对规划尤其重要，因为可以依据备选策略预期产生的未来结果，对策略评分；同样可分解为信息增益与实用价值，或期望模糊度与风险等.

第 3 章说明高路：从生物保持完整、避免耗散这一朴素要求出发，可将其描述为避免惊异状态. 我们引入马尔可夫毯，把生物内部状态与世界外部状态的统计分离形式化. 二者只能经由中间的主动变量和感觉变量，即毯状态，间接相互影响. 此统计分离对于赋予生物相对外部世界的一定自主性至关重要. 以下三个后果说明其用途.

第一，具有马尔可夫毯的生物，看上去在贝叶斯意义上为外部环境建模：其内部状态平均而言对应关于外部世界状态的近似后验信念. 第二，生物的模型，即内部状态，并非无偏，而是规定了必须维持的存在前提或先验偏好，例如鱼必须在水中，这保证了自主性. 第三，有了此形式，可以将相对于先验偏好的最优行为，描述为通过知觉和行动最大化贝叶斯模型证据. 最大化模型证据，即自我证成，使生物实现先验偏好，例如鱼留在水中，并避免惊异状态. 而模型证据最大化在数学上近似等价于变分自由能最小化；我们由另一条路，再次到达第 2 章的核心构造. 最后详述了惊异最小化与 Hamilton 最小作用量原理之间的关系，揭示主动推断与统计物理第一原理的形式联系.[17]

第 4 章概述形式方面，重点是从贝叶斯推断转到可处理的近似，即变分推断，以及由此产生的通过知觉与行动最小化变分自由能的目标. 由此可见，生物用来理解世界的生成模型极其重要. 我们介绍两类用离散或连续变量表达数据如何生成之信念的模型；二者支持相同主动推断，但分别用于把状态表述为离散时间的部分可观测马尔可夫决策问题，或连续时间的随机微分方程的情形.

第 5 章区分了自由能最小化的规范性原理，与大脑如何实现该原理的过程理论，并说明后者产生可检验预测. 随后概述主动推断的过程理论，包括神经消息传递、皮层—皮层下环路等神经解剖回路，以及神经调质. 例如，解剖层面的消息传递与典型皮层微环路对应良好：某层级深层皮层发出的预测，投向下一级浅层皮层（Bastos et al. 2012）. 系统层面上，贝叶斯推断、学习、精确度加权分别对应神经元动力学、突触可塑性、神经调质；预测编码的自上而下与自下而上神经消息传递，则对应较慢的 alpha 或 beta 节律与较快的 gamma 节律. 这些实例表明，设计具体主动推断模型后，可由生成模型形式推导神经生物学含义.

第 6 章给出模型设计步骤. 尽管所有生物都最小化变分自由能，其行为却不同，甚至相反，因为它们的生成模型不同. 因而区别简单与复杂等不同生物的，就是其生成模型. 可能的生成模型丰富多样，对应不同生物实现，例如神经实现，在不同情境与生态位中产生不同适应或不适应行为. 只要恰当刻画各自生成模型，主动推断就同样适用于感知并追寻营养梯度的细菌、追求复杂目标并参与丰富文化实践的人类，甚至不同个体. 演化似乎发现了越来越复杂的脑与身体设计，使生物能够应对并塑造丰富生态位. 建模者可逆向工程这一过程，依据生物占据的生态位，用生成模型指定其脑与身体的设计；这对应一系列设计选择，例如离散或范畴变量、浅层或层级模型，本章已逐一展开.[18]

第 7、8 章给出多个离散与连续时间实例，处理知觉推断、目标导向导航、模型学

[17]译注：本节复述作者高路论证的力度；马尔可夫毯、自主性、近似后验解释及最小作用量联系各自所需条件，仍受第 3、4 章原有假设及 ISSUES 记录约束，不能仅凭此回顾提升为无条件普遍定理.

[18]译注：前句 “离散或范畴” 照源保留；原书第 6 章的主要对比为离散与连续，二者并非此处源短语所列的互斥分类.

习、行动控制等问题，旨在展示模型下涌现行为的多样性，以及实际指定模型的原理. 第 9 章则讨论如何用主动推断做基于模型的数据分析，恢复最能解释个体任务行为的生成模型参数. 计算表型使用与本书其他部分相同的贝叶斯推断形式，但用途不同：帮助设计和评估关于他人主观模型的客观模型.

10.3 连接各点：主动推断的整合视角

几十年前，哲学家 Dennett 感叹，认知科学家过多投入于孤立子系统，例如知觉、语言理解，的建模，而其边界往往任意. 他建议改为尝试建模 “整只鬣蜥”：一个完整的认知生物，或许很简单，以及它必须应对的环境生态位（Dennett 1978）.

主动推断的优点之一，是以第一原理说明生物如何解决适应问题. 本书的规范性方法假定，可从变分自由能最小化出发，推导知觉、行动选择、注意、情绪调节等具体认知过程及其神经基础的含义.

设想一个须寻找食物或庇护的简单生物. 在主动推断下，可用生成行动的方式描述其问题：采取行动，诱发偏好的感觉，例如与食物有关的感觉. 只要这些感觉作为先验信念被纳入生成模型，生物实际上就在为模型，或更寓言式地说为自身存在，积累证据，即最大化模型证据、自我证成. 这一简单原理对传统上分开考虑的知觉、行动控制、记忆、注意、意图、情绪等功能都有影响. 知觉与行动都是自我证成：通过改变关于食物存在的信念，或改变世界、诱发食物感觉，使模型下的预期与感觉相符. 记忆与注意也可优化同一目标：长期记忆经由生成模型参数学习形成；工作记忆是关于过去、未来外部状态的信念更新；注意是优化感觉输入精确度信念. 规划与意向性可诉诸某些生物选择备选未来的能力，这又需要具有时间深度的生成模型. 它们预测某行动路线的结果，并对结果持乐观态度，表现为相信未来将导向偏好结果. 深层时间模型还可帮助理解复杂的前瞻，即由当前信念推出未来信念，和回顾，即由当前信念更新过去信念. 内感受调节和情绪则可诉诸内部生理生成模型，它预测未来事件的异稳态调节后果.

这些例子说明，从有感知行为的规范性理论研究认知与行为，有一项重要后果：不先拼装知觉、决策、规划等分立功能，而是先为生物必须解决的问题提供完整解法，再分析解法，推导认知功能的含义. 例如，哪些机制让活体或机器人等人工生物能够知觉世界、记忆世界或规划 (Verschure et al. 2003, 2014; Verschure 2012; Pezzulo, Barsalou et al. 2013; Krakauer et al. 2017)? 这一转向重要，是因为心理学与神经科学教科书的认知功能分类，大多继承早期哲学与心理学理论，有时称为 James 式范畴. 它们虽有巨大启发价值，却可能相当任意，或并不对应分离的认知与神经过程（Pezzulo and Cisek 2016; Buzsaki 2019; Cisek 2019）. 事实上，这些范畴可能适合描述我们的生成模型如何解释自身参与感觉世界，而非解释参与本身. 例如，唯我论假设 “我正在知觉”，只是我对包含自身信念更新的当前状态的解释.

规范视角还可帮助识别不同领域认知现象的形式类比. 例如探索与利用的权衡，有多种表现（Hills et al. 2015）. 觅食时，生物须在利用既有成功计划，与探索可能更好的新计划间选择；在资源有限，例如时间或搜索努力受限的记忆搜索与权衡时，也面临同样选择：利用当前最佳计划，还是投入更多时间与认知努力探索其他可能. 用自由能刻画这些表面无关现象，可能揭示深层相似性（Friston, Rigoli et al. 2015; Pezzulo, Cartoni et al. 2016; Gottwald and Braun 2020）.

最后，除了统一心理现象，主动推断还提供理解相应神经计算的原则性方法，即把认知处理与预期神经动力学相连的过程理论. 主动推断假定，与脑、心智及行为有关的一切重要方面，都可用变分自由能最小化描述；这种最小化又有可经验验证的神经特征，例如消息传递或脑解剖. 本章余下部分仿佛在勾勒心理学教科书，探索对各种心理功能的含义，并指出它与文献其他常见理论的联系或分歧.

10.4 预测的脑、预测的心智与预测加工

我有一幅纯粹欢乐的图景，
那是个持枪的孩子，
他瞄准正前方，
射击并不存在的东西.
——Afterhours，“Quello che non c’è”（并不存在的东西）

传统脑与认知理论强调从外部刺激到内部表征，再到运动行动的前馈转换，称为“三明治模型”：刺激与反应之间的一切，都贴上“认知”标签（Hurley 2008）. 这一视角中，脑的主要功能是将传入刺激转为适合情境的反应.

主动推断显著偏离这一观点，强调脑与认知的预测及目标导向方面. 心理学意义上，主动推断生物或其脑，是不断基于生成模型作预测的概率推断机器.

自我证成的生物以两种基本方式使用预测. 第一，将预测与传入数据比较，验证假设，即预测编码，并在较慢时间尺度修订模型，即学习. 第二，实施预测，引导数据获取，即主动推断. 由此满足两项要求：认知要求，例如视觉探索有显著信息、可消除假设或模型不确定性的位置；实用要求，例如移至能取得奖赏等偏好观测的位置. 前者使知觉与学习都成为主动过程，后者使行为具有目标导向.

10.4.1 预测加工

这一以预测和目标为中心的脑与认知观点，与预测加工 PP 密切相关，并启发了后者. PP 是心灵哲学与认识论中正在兴起的框架，把预测视为脑与认知的核心，诉诸“预测的脑”、“预测的心智”等概念（Clark 2013, 2015；Hohwy 2013）. PP 理论有时使用主动推断的具体运作及生成模型、预测编码、自由能、精确度控制、马尔可夫毯等构造，但有时也使用不属于主动推断的构造，例如耦合的逆向与前向模型. 所以，预测加工的用法比主动推断更广，也受较少约束.

PP 理论因多方面的统一潜力而受到哲学界关注：横跨知觉、行动、学习、精神病理等认知领域；从较低的感觉运动处理到较高的心理构造；从简单生物到脑、个体、社会与文化构造. 它还使用信念、惊异等概念术语，贴近哲学家熟悉的心理分析层面；但须注意，技术含义有时不同于日常用法.

随着兴趣增加，哲学家对 PP 理论与认识论含义的意见差异也愈发明显. 它曾被解释为内在主义（Hohwy 2013）、具身或行动取向（Clark 2015），以及生成行动主义与非表征取向（Bruineberg et al. 2016；Ramstead et al. 2019）. 这些概念解释的争论超出本书范围.

10.5 知觉

想象失焦时，不能指望眼睛.
——Mark Twain

主动推断将知觉视为基于感觉观测如何生成的模型所作的推断. 贝叶斯规则本质上反演模型，计算给定观测后关于环境隐状态的信念. 知觉即推断思想可追溯至 Helmholtz（1866），此后在心理学、计算神经科学及机器学习中反复提出，例如通过合成来分析（Gregory 1980；Dayan et al. 1995；Mesulam 1998；Yuille and Kersten 2006）. 生成建模已被证明能有效处理破解文本 CAPTCHA 验证码等困难知觉问题（George et al. 2017）.

10.5.1 贝叶斯脑假说

该思想最突出的当代表达，是应用于决策、感觉处理、学习等领域的贝叶斯脑假说（Doya 2007）. 主动推断从变分自由能最小化推导这些推断思想，为之提供规范基础. 同一要求延伸到行动动力学，因此能自然建模主动知觉，以及生物主动采样观测、检验假设的方式（Gregory 1980）. 贝叶斯脑方案则以不同要求建模知觉和行动，后者需要贝叶斯决策理论，见第 10.7.1 节.

更广义的贝叶斯脑假说是一族不一定整合、常作出不同经验预测的方法，包括计算层面的大脑进行贝叶斯最优感觉运动和多感觉整合（Kording and Wolpert 2006），算法层面的大脑实现特定贝叶斯推断近似，例如通过采样决策（Stewart et al. 2006），以及神经层面的神经种群如何作概率计算或编码分布，例如样本或概率种群编码（Fiser et al. 2010；Pouget et al. 2013）. 每个解释层面都有竞争理论. 例如，常用精确贝叶斯推断的近似来解释偏离最优的行为，但不同工作选择不同、并非总相容的近似，例如不同采样方法. 不同层次提议之间的关系也并非总直接明了，因为贝叶斯计算可用多种算法实现或近似，甚至不必显式表示概率分布（Aitchison and Lengyel 2017）.

主动推断提供连接规范原理与过程理论的更整合视角. 规范层面核心假设是所有过程都最小化变分自由能；相应推断过程理论用自由能梯度下降，有第 5 章所述的明确神经生理含义（Friston, FitzGerald et al. 2016）. 更一般地，可从自由能最小化推导脑架构的含义.

例如，连续时间知觉推断的典型过程模型是预测编码. Rao and Ballard（1999）最初将它提出为层级知觉处理理论，解释难以与前馈架构协调的一系列自上而下效应，以及感觉层级存在前向、自下而上与后向、自上而下连接等已知生理事实. 但在 Laplace 近似等假设下，预测编码可以由自由能最小化推导（Friston 2005）. 此外，为预测编码智能体配备运动反射，即可将连续时间主动推断构建为预测编码向行动领域的直接扩展（Shipp et al. 2013）. 这引向下一点.

10.6 行动控制

不能飞就跑，不能跑就走，不能走就爬，
无论怎样，都必须继续向前.
——Martin Luther King

主动推断中，行动处理类似知觉处理，二者分别由本体感受和外感受的前向预测引导. 正是 “我的手握住杯子” 的本体感受预测，诱发抓握运动. 这种等价也存在于神经生物学层面：运动皮层和感觉皮层同样组织为预测编码架构，区别是前者能影响脑干、脊髓运动反射（Shipp et al. 2013），且接受的上行输入相对少. 运动反射通过沿期望轨迹设定 “平衡点” 控制运动，对应平衡点假说（Feldman 2009）.

启动抓杯子等行动，必须适当调节先验信念和感觉流的精确度，即逆方差. 两者相对大小决定生物如何处理 “已握杯子” 的先验与 “尚未握住” 的感觉输入之间的冲突. 不精确的抓握先验容易被矛盾感觉证据修订，产生改变想法而没有行动. 若先验占主导，即精确度较高，就在矛盾证据面前维持，并诱发抓握行动消除冲突. 为保证这一点，行动启动引发短暂感觉衰减，或降低感觉预测误差权重. 感觉衰减失效可能导致不能启动或控制运动等不适应后果（Brown et al. 2013）.

10.6.1 观念运动理论

主动推断中，行动源于本体感受预测，而非运动指令（Adams, Shipp, and Friston 2013）. 这与可追溯至 William James（1890），以及后来的 “事件编码” 和 “预期行为控制” 理论（Hommel et al. 2001；Hoffmann 2003）的观念运动行动理论相连. 该理论认为，类似前向模型的行动—效应连接，是认知架构的关键机制，并可双向使用：行动至效应方向产生感觉预测；效应至行动方向选择能实现期望知觉后果的行动. 即行动依据预测后果被选择和控制，因此称为观念加运动. 一批文献记录了预期行动后果对行动选择与执行的影响，支持此预期性控制观（Kunde et al. 2004）. 主动推断为之提供数学刻画，还纳入精确度控制、感觉衰减等机制，后者在观念运动理论中未被充分研究，却与之相容.

10.6.2 控制论

主动推断与控制论关于行为目的性、目标导向性，以及基于反馈的智能体—环境互动重要性的思想密切相关，例如 TOTE，即检验、操作、检验、退出，及相关模型（Miller et al. 1960；Pezzulo, Baldassarre et al. 2006）. TOTE 与主动推断都由偏好目标状态和当前状态的差异决定行动选择，区别于行为主义和强化学习等计算框架中更常假定的简单刺激—反应关系（Sutton and Barto 1998）.

主动推断的行动控制概念尤其接近知觉控制理论（Powers 1973）. 后者核心是受控制的是知觉状态，而非运动输出或行动. 例如驾车时，在扰动中维持的是速度表指示的参考或期望速度，例如每小时 90 英里；所选加速、减速行动则更易变、更依赖情境. 风、陡坡、其他车辆等扰动不同，就可能需加速或减速维持参考速度. 这实现了 James（1890）关于人以灵活手段实现稳定目标的建议.

两种理论都是由知觉、具体为本体感受预测控制行动，但控制运作方式不同. 主动推断具有基于生成模型的预期或前馈方面，知觉控制理论则认为反馈大体足以控制行为，而预测扰动、施加前馈或开环控制没有价值. 不过，这一反对主要针对使用逆向—前向模型的控制理论之局限，见下一节. 主动推断中的生成或前向模型不用于预测扰动，而是预测要由行动实现的未来期望状态及轨迹，并推断知觉事件的潜在成因.

另一个联系是控制层级的概念化. 知觉控制理论认为，高层通过设定低层参考点或

设定点，即必须达到什么，来控制低层，同时让低层自由选择手段，而非设定或偏置低层必须执行何种行动、如何运作. 多数层级或自上而下控制理论则由高层直接选择计划（Botvinick 2008），或偏置低层行动、运动指令的选择（Miller and Cohen 2001）. 类似知觉控制理论，主动推断可把层级控制分解为自上而下的目标与子目标级联，在适当低层自主实现. 还可由动机过程调节或以精确度加权各层目标的贡献，使更显著或紧迫目标优先（Pezzulo, Rigoli, and Friston 2015, 2018）.

10.6.3 最优控制理论

主动推断解释行动控制的方式，显著不同于神经科学的最优控制等模型（Todorov 2004；Shadmehr et al. 2010）. 该框架假定运动皮层用把刺激映射到反应的反应性控制策略选择行动；主动推断则假定运动皮层传递预测.

两者虽都诉诸内部模型，却以不同方式描述内部建模（Friston 2011）. 最优控制区分两类内部模型：逆模型编码刺激—反应依存，并依据代价函数选择运动指令；前向模型编码行动—结果依存，为逆模型提供模拟输入，替代含噪或延迟反馈，超越纯反馈控制. 当前向与逆模型的输入输出被抑制时，二者也可在脱离外部行动—知觉的环路中运作，支持行动序列的内部 “如果……会怎样” 模拟. 这些模拟被联系到规划、行动知觉和社会领域的模仿（Jeannerod 2001；Wolpert et al. 2003），以及运动障碍和精神病理（Frith et al. 2000）.

主动推断中，前向生成模型承担行动控制的主要工作，逆模型极简，常化为脑干或脊髓外周层面的简单反射. 当预期与观察状态，例如期望与当前手臂位置，存在差异，即感觉预测误差时，行动启动. 因而运动指令相当于前向模型的预测，而非最优控制中逆模型计算出的东西. 本体感受预测误差由行动，即手臂运动，消除；行动需填补的差距被认为很小，无须复杂逆模型，更简单的运动反射就足够（Adams, Shipp, and Friston 2013）[1]. 反射更简单，是因为它不编码从推断世界状态到行动的映射，而编码行动与感觉后果之间更简单的映射. 进一步讨论见 Friston, Daunizeau et al.（2010）.

另一项关键区别，是最优运动控制用代价或价值函数驱动行动，而主动推断以隐含于期望自由能的贝叶斯先验或先验偏好替代之，下一节讨论.

10.7 效用与决策

行动表达优先次序.
——Mahatma Gandhi

状态的代价或价值函数，是最优运动控制、经济学效用最大化、强化学习等领域的核心. 例如最优控制中，伸手任务的最优控制策略常定义为最小化特定代价函数的策略，例如更平滑或加加速度最小. 在含一个或多个奖赏的迷宫导航等强化学习问题中，最优策略使折扣奖赏最大，同时使运动代价最小. 常用 Bellman 方程，连续时间中用 Hamilton–Jacobi–Bellman 方程，求解. 总体思想是把决策价值分解为即时奖赏和剩余决策问题的价值，支持动态规划的迭代程序，后者是控制理论与强化学习 RL 的核心（Bellman 1954）.

主动推断有两项主要区别. 第一，不仅考虑效用最大化，而考虑更广的期望自由能最小化，含消除当前状态歧义、新奇寻求等认知要求，见图 2.6. 这些目标有时作为 “新奇奖励”（Kakade and Dayan 2002）或 “内在奖赏”（Schmidhuber 1991；Oudeyer et al. 2007；Baldassarre and Mirolli 2013；Gottlieb et al. 2013）附加于经典奖赏，却在主动推断中自动产生，使其解决许多决策隐含的探索—利用权衡. 原因是自由能是信念的泛函，优化的是信念，而非外部奖赏函数. 这对成功依赖尽可能消除不确定性的探索问题至关重要.

第二，代价概念被吸收到先验中. 先验或先验偏好指定控制目标，例如要遵循的轨迹或到达的终点. 相比效用，用先验编码偏好观测或序列，可能更有表达力（Friston, Daunizeau, and Kiebel 2009）. 于是寻找最优策略转成推断实现偏好轨迹的控制状态序列，无须价值函数或 Bellman 方程，尽管可以诉诸类似递归逻辑（Friston, Da Costa et al. 2020）. 主动推断的先验与 RL 的价值函数在通常用法上至少有两个根本区别. 其一，RL 使用状态或状态—行动对的价值函数，主动推断使用观测先验. 其二，价值函数以特定策略下处于某状态，或在该状态采取某行动，的期望回报定义，即从该状态开始执行策略获得的未来折扣奖赏之和. 主动推断先验通常不求和或折扣未来奖赏；类似期望回报的量，只在计算策略期望自由能时涌现. 所以期望自由能最接近价值函数，但它是状态信念的泛函，而非状态函数. 不过，也能通过在状态中缓存期望自由能计算，构建类似 RL 状态价值函数的先验（Friston, FitzGerald et al. 2016；Maisto, Friston, and Pezzulo 2019）.

将效用吸收到先验还有重要理论后果：先验扮演目标，使生成模型有偏或乐观，即生物相信会遇到偏好结果. 正是这种乐观支持推断出实现期望结果的计划；其失效可能对应淡漠（Hezemans et al. 2020）. 贝叶斯决策理论等其他形式方法则分开事件概率与效用. 但此区分有些表面，因为效用函数总可改写为先验信念：最大化效用的行为，先验上、按设计就更可能. 从一种略带同义反复的朴素观点看，这就是效用的定义.[19]

10.7.1 贝叶斯决策理论

贝叶斯决策理论把上述贝叶斯脑思想扩展到决策、感觉运动控制和学习（Kording and Wolpert 2006；Shadmehr et al. 2010；Wolpert and Landy 2012）. 它把决策描述为两个过程：先用贝叶斯计算预测依赖行动或策略的未来结果概率，再用固定或学习到的效用、代价函数定义计划偏好. 最终决策或行动选择整合两条流，更可能选择更有可能产生更高奖赏的计划. 主动推断则由先验分布直接表示对生物有价值的东西，或演化史中有价值的东西. 但可将贝叶斯决策理论两条流，分别类比于变分与期望自由能优化：前者产生关于世界状态及可能演化的准确且简单信念；关于策略选择会使期望自由能最小的先验，则纳入偏好概念.

有些研究者担忧贝叶斯决策理论的地位，缘于完全类定理（Wald 1947；Brown 1981）：对任意给定的决策与代价函数配对，存在使该决策贝叶斯最优的先验信念. 这表示分开处理先验信念与代价函数，隐含某种对偶或简并. 某种意义上，主动推断通过将效用或

[19]译注：将任意效用函数改写为归一化先验分布，仍需相应可积性、支撑集与尺度约定；源此处未列这些条件，保留其概括，不据此保证任意无界效用都定义概率分布.

代价函数作为偏好吸收到先验，解决此简并.[20]

10.7.2 强化学习

强化学习是求解马尔可夫决策问题的方法，在人工智能与认知科学都很常见（Sutton and Barto 1998）. 它关注智能体如何通过试错学习平衡杆等策略：尝试向左移动等行动，依据杆保持平衡还是倒下等成功或失败，获得正负强化.

主动推断与 RL 处理的问题重叠，但在数学和概念上多有不同. 前者不用 RL 核心的奖赏、价值函数、Bellman 最优性概念. “策略” 的含义也不同：RL 中是要学习的一组刺激—反应映射；主动推断中则是生成模型的一部分，表示要推断的控制状态序列.

RL 方法繁多，可分为三大类. 前两类以不同方式学习良好的状态或状态—行动价值函数. 无模型 RL 直接从经验学习：执行行动、收集奖赏、更新价值函数，再用它们更新策略. 称为无模型，是因为不用主动推断那类能够预测未来状态的转移模型；它隐式依赖状态—行动映射等更简单模型. 学价值函数常计算奖赏预测误差，例如时间差分规则. 主动推断虽也常用预测误差，但由于没有奖赏概念，用的是状态预测误差.

基于模型 RL 不直接从经验学价值函数或策略，而先从经验学习任务模型，再用模型规划、模拟可能经验，由模拟经验更新价值函数与策略. 两者都用基于模型规划，但用法不同：主动推断的规划是计算各策略的期望自由能，而非更新价值函数的手段. 若把期望自由能视为价值泛函，也可以说生成模型所得推断用于更新此泛函，从而构成类比.

第三类策略梯度方法不经中间价值函数，直接优化策略，而价值函数是前两类 RL 的核心. 它从能产生运动轨迹等的参数化策略出发，改变参数，在轨迹产生高或低正奖赏时，增大或减小相应策略的似然. 这使其与同样不用价值函数的主动推断有关（Millidge 2019），但最大化长期累积奖赏的总体目标不同.

还有若干重要概念区别，例如如何解释目标导向与习惯行为. 动物学习文献中，目标导向选择由行动与结果依存关系的前瞻知识介导（Dickinson and Balleine 1990）；习惯选择不具前瞻性，依赖刺激—反应等更简单机制. RL 中常把二者分别对应基于模型与无模型 RL，认为并行习得，持续竞争行为控制权（Daw et al. 2005）.

主动推断则映射到其他机制. 离散时间主动推断的策略选择本质上基于模型，符合目标导向、审慎选择的定义. 它类似基于模型 RL，但后者以前瞻方式、用模型选择行动，却以反应方式、用刺激—反应策略控制行动；主动推断可以通过实现本体感受预测，以主动的方式控制行动，见第 10.6 节.

主动推断可通过执行目标导向策略，再缓存哪些策略在何种情境成功的信息，获得习惯；缓存可纳入策略先验价值（Friston, FitzGerald et al. 2016；Maisto, Friston, and Pezzulo 2019），让给定情境中先验价值高的策略无须权衡就可执行. 可以理解为多次接触任务后，观察 “我做什么”，学到 “我就是倾向于这样做的生物”. 无模型 RL 中习惯独立于目标导向策略选择习得，而主动推断中，习惯通过反复执行目标导向策略，例如缓存结果，获得.

二者在主动推断中不只竞争，也可合作，因为策略先验同时依赖习惯项，即策略先

[20]译注：这里依作者概括保留完全类定理的表述；具体定理版本、决策类、容许性和先验条件，仍需与框 6.2 既有译注一并核查，不把任意决策的无条件表述另行确立为定理.

验价值，和审慎项，即期望自由能. 层级扩展还提示，反应性和目标导向机制可按层级组织，而非并行通路（Pezzulo, Rigoli, and Friston 2015）. 最后，两者对行为与成因的理解也略有不同：RL 源于行为主义，把行为视为强化介导的试错学习结果；主动推断则假定行为是推断的结果. 这引向下一点.

10.7.3 规划即推断

正如知觉问题可表述为推断问题，控制问题也可用近似贝叶斯推断表述（Todorov 2008）. 主动推断据此将规划视为生成模型中控制状态序列的推断.

它与控制即推断（Rawlik et al. 2013；Levine 2018）、规划即推断（Attias 2003；Botvinick and Toussaint 2012）、风险敏感控制及 KL 控制（Kappen et al. 2012）密切相关. 这些方法用编码状态、行动、未来预期状态间概率依存的动态生成模型，推断行动或行动序列的后验，从而规划. 以观察到未来奖赏（Pezzulo and Rigoli 2011；Solway and Botvinick 2012）或最优未来轨迹（Levine 2018）为条件，可推断最佳行动或计划. 例如，钳制、固定模型中的未来期望状态，再推断最可能填补当前状态至未来期望状态差距的行动序列.

主动推断、规划即推断及相关方案采用前瞻控制，从未来将被观测状态的显式表征出发，而不是最优控制和 RL 更典型的刺激—反应规则或策略集. 不过，具体实现至少有三个差异维度：使用何种推断，例如采样或变分推断；推断什么，例如行动或行动序列的后验；推断目标是什么，例如最大化最优性条件的边缘似然，或获得奖赏的概率.

主动推断在各维度都有其特有视角. 第一，以可扩展的近似方案，即变分推断，处理规划即推断中的困难计算问题. 第二，支持基于模型规划，推断控制状态的后验，这对应行动序列或策略，而非单个行动[2]. 第三，推断序列时考虑期望自由能泛函，它在数学上涵盖 KL 控制等广泛使用的方案，并能处理模糊情境（Friston, Rigoli et al. 2015）.

10.8 行为与有限理性

> 智者受理性教导，常人受经验教导，
> 愚者受必要性教导，野兽受本能教导.
> ——Marcus Tullius Cicero

主动推断中的行为自动结合审慎、固着与习惯成分（Parr 2020）. 设想一人步行去家附近商店；预测左转或右转等行动后果，就能制定好计划. 这一审慎方面由期望自由能提供：以实现到达商店等偏好观测的方式行动，便使它最小. 期望自由能还驱动降低不确定性，可以表现为权衡. 若不确定最佳方向，她可以绕远一点，去适当观察点，方便找到去商店的路；计划由此具有认知可供性.

若因分心等较难进行权衡，她可能到商店后仍继续走. 这一固着方面由变分自由能提供：获得与当前信念、包括当前行动路线信念相容的观测，就使它最小. 感觉与本体感受观测为 “行走” 提供证据，所以缺少权衡时可维持固着. 另一种可能，是不假思索选择平常回家的计划. 这一习惯成分来自策略先验价值：过去反复见自己执行回家计划，便为它分配高概率；若没有审慎过程取代，它即可占主导.

审慎、固着、习惯可共存并结合；即可以推断，此时习惯是最可能行动路线. 这不同于假定理性和直觉两套独立驱动系统的 “双重理论”（Kahneman 2017）. 三成分的混合，可能依赖经验量、可投入审慎过程的认知资源等情境条件，因为审慎可能有很高复杂度代价[3].

认知资源对决策的影响，已在有限理性名下被广泛研究（Simon 1990）. 核心是，理想理性智能体应始终充分考虑行动结果，而有限理性智能体须权衡计算的代价、努力与及时性，例如权衡最佳计划的信息处理代价（Todorov 2009；Gershman et al. 2015）.

10.8.1 有限理性的自由能理论

有限理性曾用 Helmholtz 自由能最小化表述；这是与主动推断变分自由能严格相关的热力学构造，详见 Gottwald and Braun（2020）. “有限理性的自由能理论” 以能量与熵两项，表达信息处理能力有限时行动选择的权衡，见第 2 章. 前者代表选择的期望价值，是准确度项；后者代表审慎的代价，是复杂度项. 审慎中有代价的是在选择之前降低信念的熵，或复杂度，使其更精确（Ortega and Braun 2013；Zénon et al. 2019）. 直观上，后验越精确，选择越准确，可能效用越高；但提高精确度有代价，决策者须通过自由能最小化求折中. 同样权衡在主动推断中产生有限理性. 这一概念也呼应证据或边缘似然的变分界，后者是主动推断的决定性方面. 因而它提供有限理性与最优性的模型：最佳解来自准确度和复杂度的折中. 这些目标源于比经济学通常考虑的效用最大化更丰富的规范性自由能最小化要求.[21]

10.9 效价、情绪与动机

> 想想你们的出身：你们生来不是为了如野兽般生活，
> 而是为了追求美德与知识.
> ——Dante Alighieri

主动推断把负自由能作为适合度及生物实现目标能力的度量. 生物虽被认为行动以最小化自由能，却不必计算它；一般处理梯度已足够. 如同不必知道海拔，只需沿上坡就可找山顶. 但有人提出，生物可能建模自由能随时间如何变化，以刻画效价、情绪、动机等现象.

据此，情绪效价，即情绪正负性质，可被构想为自由能对时间的变化率或一阶导数（Joffily and Coricelli 2013）. 自由能随时间增加，生物可赋情境负效价；降低则赋正效价. 延伸到长期动力学及二阶时间导数，可望刻画更复杂情绪，例如从低效价转至高效价的释然，或从高到低的失望. 监测自由能动力学及引发的情绪，可能让行为策略或学习率适应长期环境统计.

假定第二个生成模型专门监测第一个模型的自由能，似乎跨越很大；但这些想法也有另一解释. 可考虑什么引起自由能快速变化：它是信念泛函，所以快速变化必由快速信念更新引起. 速度的关键决定因素是精确度，它在预测编码动力学中起时间常数作用.

[21] 译注：此处 “熵（或复杂度）” 沿用源文概括；变分推断的复杂度通常是后验相对先验的 KL 散度，并非一般等于熵. 本段热力学自由能与变分自由能的联系，依所引工作的具体构造，不把名称相近当作无条件同一性.

这也联系到自由能高阶导数，因为精确度是自由能二阶导数，即景观曲率，的负值.[22] 不过，为什么把精确度与效价关联？答案是精确度与模糊度反向相关：越精确，解释越少歧义. 选择最小期望自由能的行动路线，也意味着最小模糊度，因而最大精确度. 由此看到自由能高阶导数、变化率和动机行为的直接联系.[23]

对自由能增加或减少的预期，也可起动机与激励作用. 主动推断中，策略信念精确度是自由能变化预期的一个替代量，再次突出二阶统计的重要性. 例如，高精确度信念表示已找到好策略，可确信其会使自由能最小. 策略信念精确度已被联系到多巴胺信号（FitzGerald, Dolan, and Friston 2015）；提高它的刺激引发多巴胺爆发，可能表示激励显著性（Berridge 2007）. 这一视角可帮助阐明，将目标或奖赏实现的预期，与注意（Anderson et al. 2011）和动机（Berridge and Kringelbach 2011）增加相连的神经生理机制.

10.10 稳态、异稳态调节与内感受加工

身体里有比你最深邃哲学更多的智慧.
——Friedrich Nietzsche

生成模型不仅关于外部世界，也关于、或许更重要地关于内部环境. 身体内部的生成模型或内感受图式有双重作用：解释躯体内感受如何生成，并保证体温、血糖等生理参数的正确调节（Iodice et al. 2019）. 第 10.6.2 节所述控制论认为，生物的核心目标是维持稳态（Cannon 1929），使生理参数保持可生存范围，例如体温不过高；稳态只有成功控制环境才可实现（Ashby 1952）.

主动推断可以把可生存范围指定为内感受观测先验，实现稳态调节，并能以多种嵌套方式进行. 最简单环路是在某些参数预期超范围，例如体温过高时，调动血管扩张等自主神经反射. 可将它构建为作用于内感受流的内感受推断，区别于外向行动中的本体感受流（Seth et al. 2012；Seth and Friston 2016；Allen et al. 2019）. 脑可用生成模型预测内感受和生理流，触发自主反射纠正意外高体温等预测误差，类似运动反射纠正本体感受误差、引导外向行动.

主动推断还能以越来越复杂方式纠正同一高体温误差（Pezzulo, Rigoli, and Friston 2015）. 可用超越稳态的预测性异稳态策略（Sterling 2012；Barrett and Simmons 2015；Corcoran et al. 2020），在误差触发前预先控制生理，例如过热前寻找阴凉. 另一策略是在预期偏离生理设定点前动员资源，例如长跑前增加心输出量，预期氧需求增加；这须动态改变内感受观测先验，超越稳态（Tschantz et al. 2021）. 最终，预测脑可发展更复杂目标导向策略，例如确保带冷水去海滩，以更丰富有效方式实现控制体温的同一要求.

生物与内感受调节对情感、情绪加工可能至关重要（Barrett 2017）. 情境互动时，脑不断预测接下来发生什么，以及对内感受和异稳态调节的后果. 在知觉外部对象、事

[22]译注：上一句按源物理 225 页保留. 对本书负对数联合密度或局部自由能的通常 Laplace 约定，后验精确度对应正的 Hessian；源此处“自由能二阶导数的负值”与第 4 章对数密度约定之间有符号疑点，未静默更正. 时间导数与对信念坐标的 Hessian 也不是同一种导数.

[23]译注：期望自由能还含风险或实用价值等项，整体最小化一般不保证其模糊度分项单独达到最小. 这里保留作者的概括性关联，不扩大为各分项可同时独立最优的保证.

件时诱发的内感受流，赋予它们情感维度，表示其对生物调节和生存的好坏，使之具有“意义”. 若此观点正确，这类加工障碍可能引发情绪失调与各种精神病理（Pezzulo 2013; Barrett et al. 2016; Maisto, Barca et al. 2019; Pezzulo, Maisto et al. 2019）.

内感受推断还有正在兴起的伴侣：情绪推断. 这一应用将情绪视为生成模型的一部分，是脑在深层生成模型中部署精确度的另一构造或假设. 从信念更新看，焦虑只是对最能解释当前感觉与内感受线索的贝叶斯信念“我很焦虑”的承诺. 从行动看，随后的内感受预测增强或衰减各种精确度，即隐性行动，或支配自主神经反应，即显性行动；它看起来很像唤醒，证实“我很焦虑”的假设. 情绪推断通常跨领域整合内、外感受信息，因此情绪、内感受、注意在健康（Seth and Friston 2016; Smith, Lane et al. 2019; Smith, Parr, and Friston 2019）与疾病（Peters et al. 2017; J. E. Clark et al. 2018）中关系密切.

10.11 注意、显著性与认知动力学

真正的无知不是没有知识，而是拒绝获取知识.
——Karl Popper

仅本章就多次提到精确度和期望自由能，若不给注意与显著性留一点篇幅，便是疏忽. 这些概念贯穿心理学，反复被重新定义、分类：有时指优先选择某感觉模态或其中通道子集的突触增益控制（Hillyard et al. 1998）；有时指通过显性或隐性行动定向，以获得更多世界信息（Rizzolatti et al. 1987; Sheliga et al. 1994, 1995）.

多义性带来的不确定性，虽使此领域具有一些认知吸引力，消除模糊也有价值. 形式化心理学的优点，是无须担心这一歧义：可把注意操作性定义为某感觉输入的精确度. 它自然对应增益控制，因为推断为更精确的感觉，比不精确感觉更影响信念更新. 该联系的构造效度，已在著名 Posner 范式等心理学范式中展示（Feldman and Friston 2010）：视觉空间某位置获更高精确度时，对该处刺激反应更快.

显著性也需类似形式定义. 主动推断通常把它关联到期望信息增益或认知价值，即期望自由能的一个成分. 预期提供更多信息的东西更显著；但这是按行动或策略定义，注意则是感觉输入信念的属性，契合显著性作为显性、隐性定向的概念. 第 7 章还把期望信息增益细分为显著性与新奇性，分别是推断潜力与学习潜力. 以科学实验设计与分析类比：注意是在已有测量中选最高质量数据，用于假设检验；显著性则设计下一实验，确保最高质量数据.

讨论这些不是再添一套注意现象分类，而是突出采用形式心理学的优点. 他人即使不同定义注意或任何构造，也可直接指明数学构造，避免混淆. 最后，这些定义也简单解释了两者为何常混用：高精确度数据模糊度低，应获注意，而获取它们的行动也高度显著（Parr and Friston 2019a）.

10.12 规则学习、因果推断与快速泛化

昨天我聪明，想改变世界；今天我智慧，正在改变自己.
——Rumi

人和其他动物善于复杂因果推断、抽象概念学习、物体间因果关系学习，以及从有限经验泛化. 相比之下，本书写作时的机器学习范式须大量样本才能达相似表现，提示这些主要基于复杂模式识别的方法，可能尚未完全捕捉人的学习思考方式（Lake et al. 2017）.

主动推断的学习范式发展捕捉行动、事件、观测间因果关系的生成模型. 本书 T 形迷宫等任务相对简单，所需模型也简单. 复杂情境的理解推理则需捕捉环境潜在结构的深层生成模型，例如隐蔽规律可让人跨表面不同情境泛化（Tervo et al. 2016；Friston, Lin et al. 2017）.

交通路口是支配复杂社会互动的隐规则的简单例子. 一个不熟悉情况的人观察繁忙路口，须预测或解释行人与车辆何时过路；他可积累红车停下、高个男人过路、老妇停下、大车驶过等共现统计，但多数最终无用. 最后可能发现，所有车在某处停下后，行人很快过路等重复模式. 若机器学习任务只是预测行人何时将走，这已足够，却不意味着理解情境；甚至可能误认为停车解释了行人移动. 不诉诸因果模型的应用常犯此类错误，无法区分是下雨解释湿草，还是湿草解释下雨（Pearl and Mackenzie 2018）.

推断正确的交通灯等隐规则，则更深入理解因果结构：是灯使车停、人走. 隐规则不但预测更好，还能忽略车色等多数感觉细节，使推断更简约，从而泛化到感觉细节很不同的其他路口或城市；当然，在罗马等城市，过路口可能不止要看交通灯. 学习规则还能提高新情境学习效率，形成心理学的 “学习定势”，或机器学习的学会学习能力（Harlow 1949）. 若灯不亮，不能用旧规则，但仍可预期另一相似隐规则在起作用，有助理解交警在做什么.

此例说明，学习环境潜在结构的丰富生成模型，即结构学习，支持复杂因果推理与泛化. 扩展模型以处理这些复杂情境，是计算建模和认知科学持续目标（Tenenbaum et al. 2006；Kemp and Tenenbaum 2008）. 当前机器学习 “越大越好” 的趋势，与主动推断强调准确度—复杂度平衡、偏向简单模型的统计方法，存在张力. 模型约简、剪去无用参数，不仅避免浪费资源，也能有效学习隐规则，包括睡眠等离线期（Friston, Lin et al. 2017），或许表现为静息态活动（Pezzulo, Zorzi, and Corbetta 2020）.

10.13 主动推断与其他领域：开放方向

总得从某地开始，总得从某时开始，
还有比这里更好的地方，比现在更好的时候吗?
——Rage Against the Machine，“Guerrilla Radio”

本书主要关注生物生存与适应问题，却也可用于其他许多领域. 最后简述社会文化动力学，以及机器学习与机器人学. 前者须考虑多个主动推断智能体如何互动及涌现效应；后者须理解如何在相容于理论基本假设的前提下，赋予更有效学习、推断机制，扩展到复杂问题. 两者都是有趣开放方向.

10.13.1 社会与文化动力学

人类认知的许多有趣方面，涉及社会文化动力学，而非个人知觉、决策、行动（Veissière et al. 2020）. 社会动力学按定义须多个生物进行物理互动，例如团队运动等联合

行动，或选举、社交网络等更抽象互动. 相同生物间简单的相互主动推断演示，已产生有趣涌现现象：抵抗弥散的简单生命自组织，通过形态发生获得、恢复体形，以及相互协调预测和轮流（Friston 2013；Friston and Frith 2015a；Friston, Levin et al. 2015）. 其他模拟处理生物如何将认知延伸至物质人工制品、塑造认知生态位（Bruineberg et al. 2018）.

这些模拟只捕捉社会文化复杂性的一小部分，却展示主动推断从个体科学扩展到社会科学，以及认知如何超越颅骨的潜力（Nave et al. 2020）.

10.13.2 机器学习与机器人学

本书的生成建模与变分推断，广泛用于机器学习和机器人学；这些领域常强调如何学习联结主义生成模型，而非本书关注的如何用之作主动推断. 这些方法可能扩展生成模型及所处理问题的复杂度，但也可能调用很不同的主动推断过程理论.

无法全面回顾机器学习生成建模文献，只简提若干常见模型及其大量变体. 早期 Helmholtz 机器和 Boltzmann 机器（Ackley et al. 1985；Dayan et al. 1995）示范无监督学习神经网络内部表征. Helmholtz 机器尤其接近主动推断的变分方法，使用分立识别与生成网络，推断隐变量分布，并从中采样取得虚拟数据. 早期实践成功有限；后来堆叠多个受限 Boltzmann 机器，支持多层内部表征学习，成为无监督深层网络的早期成功（Hinton 2007）.

较新的变分自编码器 VAE（Kingma and Welling 2014）与生成对抗网络 GAN（Goodfellow et al. 2014），广泛用于图片视频识别或生成. VAE 优雅地把变分方法用于生成网络学习，目标证据下界 ELBO 在数学上等价于变分自由能.[24] 此目标让网络准确描述数据，最大化准确度，又偏好内部表征不要过度偏离先验，最小化复杂度. 后者是所谓正则化，有助泛化、避免过拟合.

GAN 则将生成网络与判别网络结合，学习时不断竞争. 判别网络学习区分样本是真实还是生成网络产生的虚拟数据；生成网络努力产生能欺骗、使判别网络误分类的虚拟数据. 竞赛迫使生成网络改善能力，产生高保真虚拟数据，广泛用于逼真图像生成等.

上述及其他模型也可用于控制. Ha and Eck（2017）用序列至序列 VAE 学习预测铅笔笔画，从内部表征采样，构建新的笔画图. 生成建模也用于机器人运动控制，有些直接使用主动推断（Pio-Lopez et al. 2016；Sancaktar et al. 2020；Ciria et al. 2021），或在联结主义情境中使用相近思想（Ahmadi and Tani 2019；Tani and White 2020）.

主要挑战之一，是机器人运动高维，需要学习复杂生成模型. 主动推断及相关方法有趣之处，在于最重要的学习对象是从行动到下一时间步视觉、本体感受等感觉反馈的前向映射. 可通过自主探索、示范，甚至与人直接互动学习，例如教师或实验者沿到目标的轨迹引导机器人双手，支撑有效目标导向行动的习得（Yamashita and Tani 2008）. 多种学习方式极大扩展最终可实现的技能范围. 反过来，主动推断下更先进的神经机器人，对技术和理论都可能重要，因为适应性智能体—环境互动、认知功能整合、具身性重要性等关键方面，在机器人场景中自然得到处理.

[24]译注：按本书以自由能为证据负对数上界的约定，通常 ELBO $= -F$，最大化前者等价于最小化后者，而非二者数值同号相等；源文 “数学上等价” 按目标优化的对应理解.

10.14 小结

家园已在身后，世界尚在前方，
还有许多路要走，
穿越阴影，直到夜的边缘，
直到所有星辰点亮.
——J. R. R. Tolkien，《指环王》

本书开头询问，能否从第一原理理解脑与行为，再把主动推断引入为迎接此挑战的候选理论. 希望读者已被说服，对最初问题可以回答 “是”. 本章讨论其对有感知行为的统一视角，以及对知觉、行动选择、情绪等熟悉心理构造的含义，借此回顾全书概念，并提醒仍有引人入胜的问题等待未来研究. 希望本书为主动推断的相关哲学著作（Hohwy 2013；Clark 2015）与物理著作（Friston 2019a）提供有用补充.

Appendix A

数学背景

A.1 引言

本附录介绍或复习全书使用的基本数学技术，非穷尽地概述线性代数、Taylor 级数近似、变分法和随机动力学四个主题，并指出它们在书中何处发挥作用. 目的在于有针对性地建立直觉，而非提供形式化严格证明. 理解和使用主动推断所需数学并不复杂，但其多学科基础使人往往难以找到汇集所有先修知识的资料，希望本附录能有所弥补.

A.2 线性代数

A.2.1 基础

线性代数是一种简洁表达乘法与求和组合的记号，依靠由多行多列数字数组构成的矩阵和多行单列的向量. 矩阵 A 第 i 行、第 j 列元素记为 A_{ij}. 两矩阵 B、C，或矩阵与向量，之积 A 定义为

$$A = BC \quad \Longrightarrow \quad A_{ij} = \sum_k B_{ik} C_{kj}. \tag{A.1}$$

此定义要求 B 的列数与 C 的行数相同. 不过，设 B 的列数与 C 的列数相同，而想表达

$$A_{ij} = \sum_k B_{ki} C_{kj}. \tag{A.2}$$

译注：本句 “列数与列数” 照源保留；式 (A.2) 的求和实际上要求 B 与 C 的行数相同，列数则不必相同.

怎样用线性代数表达？须交换 B 的下标，即反射数组，使行列互换，这就是通常以上标 T 表示的转置：

$$\begin{aligned} B^T_{ik} &\triangleq B_{ki}, \\ A = B^T C \triangleq B \cdot C \quad &\Longrightarrow \quad A_{ij} = \sum_k B_{ki} C_{kj}. \end{aligned} \tag{A.3}$$

第二行还突出点号的替代记法；它受到 B、C 各只有一列时，本式化为向量点积的启发.

另一个有用运算是迹：把方阵主对角线上元素相加，

$$\mathrm{tr}[A] \triangleq \sum_i A_{ii}. \tag{A.4}$$

其用途部分来自矩阵积之迹中各项的循环置换：

$$\begin{aligned}\operatorname{tr}[ABC] &= \sum_i \sum_j \sum_k A_{ij} B_{jk} C_{ki} \\ &= \sum_k \sum_i \sum_j C_{ki} A_{ij} B_{jk} = \operatorname{tr}[CAB] \\ &= \sum_j \sum_k \sum_i B_{jk} C_{ki} A_{ij} = \operatorname{tr}[BCA]. \end{aligned} \tag{A.5}$$

全书主要把此恒等式用于标量. 标量可视为一行一列矩阵，取迹不改变它；因而矩阵积若为标量，就可如上置换. 例如 B 为 $N \times N$ 方阵，c 为 N 行向量，则

$$\begin{aligned} a = c \cdot Bc &= \operatorname{tr}[c^T Bc] = \operatorname{tr}[Bcc^T] = \operatorname{tr}[BC], \\ C = c \otimes c &\triangleq cc^T. \end{aligned} \tag{A.6}$$

这将二次式改写为两矩阵积的迹；最后一行定义外积，以区别于内点积. 第 A.2.3 节将见它对多元正态分布尤其有用.

还需了解逆与行列式. 逆定义为

$$A^{-1}A = AA^{-1} = I. \tag{A.7}$$

矩阵与逆的乘积是单位矩阵，即主对角线为 1、其余为 0 的方阵. 任意矩阵乘单位矩阵不变，类似标量乘 1；1 也可视为一维单位矩阵. 所以先乘某矩阵再乘其逆，就回到原量.[25]

行列式有用，但较难建立直观. 本书中它只作为多元正态分布归一化常数的一部分出现，值得知道计算方法，不作详述. 递归定义为

$$|A| \triangleq \sum_i (-1)^{i-1} A_{1i} |A_{\setminus(1,i)}|. \tag{A.8}$$

$A_{\setminus(1,i)}$ 表示删去第 1 行、第 i 列的矩阵. 例如

$$\begin{aligned} A &= \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \\ A_{\setminus(1,1)} = A_{22}, &\qquad A_{\setminus(1,2)} = A_{21}, \\ |A| = A_{11}|A_{22}| - A_{12}|A_{21}| &= A_{11}A_{22} - A_{12}A_{21}. \end{aligned} \tag{A.9}$$

译注：源中 $|A_{22}|$、$|A_{21}|$ 在此是 1 阶矩阵行列式，不是标量绝对值. “只作为归一化常数出现” 是作者概述；第 9 章还把行列式写进证据近似. 至此结束基本运算概述.

A.2.2 导数

矩阵与向量微分，直接对每个元素应用通常微积分. 若矩阵 B 的元素是标量 x 的函数，则

$$\begin{aligned} A(x) = \partial_x B(x) \quad &\Longrightarrow \quad A(x)_{ij} = \partial_x B(x)_{ij}, \\ \partial_x &\triangleq \frac{\partial}{\partial x}. \end{aligned} \tag{A.10}$$

[25] 译注：这里默认所论方阵可逆，乘法的维数与次序相容；奇异矩阵不具有式示双侧逆.

以下定义与恒等式有助理解本书细节. 首先是对非标量求导：向量 b 是另一向量 c 的函数时，其导数为矩阵，

$$A = \partial_c b(c) \quad \Longrightarrow \quad A_{ij} = \partial_{c_j} b(c)_i. \tag{A.11}$$

还使用对向量求导的梯度算子：

$$\begin{aligned} \nabla_b &= \begin{bmatrix} \partial_{b_1} & \partial_{b_2} & \partial_{b_3} & \cdots \end{bmatrix}^T, \\ a = \nabla_b x(b) \quad &\Longrightarrow \quad a_i = \partial_{b_i} x(b). \end{aligned} \tag{A.12}$$

将梯度定义为导数算子向量，还能简洁定义向量函数的散度：

$$\nabla_a \cdot b(a) = \sum_i \partial_{a_i} b(a)_i. \tag{A.13}$$

线性代数量有许多导数恒等式，不作全面介绍，深入可读 *The Matrix Cookbook*（Petersen and Pedersen 2012）. 这里只限于两项有用恒等式，第一是二次量梯度：

$$\begin{aligned} d(a) &= \nabla_a \big(b(a) \cdot Cb(a)\big), \\ d(a)_i &= \partial_{a_i} \sum_j \sum_k b(a)_j C_{jk} b(a)_k \\ &= \sum_j \sum_k \left[(\partial_{a_i} b(a)_j) C_{jk} b(a)_k + (\partial_{a_i} b(a)_k) C_{jk} b(a)_j \right], \\ d(a) &= \nabla_a b(a) \cdot (C + C^T) b(a). \end{aligned} \tag{A.14}$$

这里及全书，点号蕴含的转置先于梯度算子：

$$\nabla_a b(a) \cdot (\ldots) \triangleq \nabla_a b(a)^T (\ldots) \neq \big(\nabla_a b(a)\big)^T (\ldots). \tag{A.15}$$

式 (A.14) 用于第 4 章预测编码信念更新式的推导. 第二项是同一量对矩阵 C 的导数：

$$\begin{aligned} D(a) &= \nabla_C \big(b(a) \cdot Cb(a)\big), \\ D(a)_{ij} &= \partial_{C_{ij}} \sum_k \sum_l b(a)_k C_{kl} b(a)_l = b(a)_i b(a)_j, \\ D(a) &= b(a) \otimes b(a). \end{aligned} \tag{A.16}$$

带矩阵下标的梯度表示

$$\nabla_C = \begin{bmatrix} \partial_{C_{11}} & \partial_{C_{12}} & \cdots \\ \partial_{C_{21}} & \partial_{C_{22}} & \\ \vdots & & \ddots \end{bmatrix}. \tag{A.17}$$

附录 B 将见式 (A.16) 如何帮助估计后验协方差矩阵.

A.2.3 概率

上述恒等式在两类概率推理中发挥作用：随机变量，即分布支撑集中的对象，是向量；或分布的充分统计量是向量、矩阵、高阶张量[1]. 多元正态分布同时是二者的例子：

$$p(x) = \left[\left(\frac{1}{2\pi}\right)^k |\Pi|\right]^{1/2} e^{-\frac{1}{2}(x-\eta)\cdot\Pi(x-\eta)},$$
$$\dim(x) = k. \tag{A.18}$$

x 为 k 维向量，众数 η 也是. 精确度 Π 为协方差的逆；协方差是表示概率质量围绕众数分散程度的 $k \times k$ 对称矩阵. Π 在式中出现两次：归一化常数中的行列式，以及指数中. 指数的二次项是标量，可用式 (A.6)，对附录 B 很重要.[26]

范畴分布的充分统计量，直接就是概率的向量、矩阵或张量. 例如六面骰结果分布为 6 维向量，各分量表示对应点数概率. 条件概率更有意思：变量 o、s 各有若干可能值，给定 s 的 o 条件概率可写为矩阵，

$$P(o = i \mid s = j) = A_{ij}. \tag{A.19}$$

即给定 s 的第 j 值，o 取第 i 值的概率，是 A 第 i 行第 j 列元素. 条件集有多个变量时形成张量：

$$P(o = i \mid s_1 = j, s_2 = k, s_3 = l, \ldots) = A_{ijkl\ldots}. \tag{A.20}$$

可以任意增加条件变量和下标，得到任意阶张量. 第 7 章 T 形迷宫使用 3 阶概率张量，其原理可推广. 对张量，全书用点号表示对第一个下标求和：

$$A = B \cdot x \quad \Longrightarrow \quad A_{jklm\ldots} = \sum_i B_{ijklm\ldots} x_i. \tag{A.21}$$

将分布表达为数字数组，便能用前两节定义简洁计算相关量. 例如熵是负的期望或平均对数概率，对式 (A.19) 有

$$\begin{aligned} H[P(o \mid s)] &\triangleq -\mathbb{E}_{P(o|s)}[\ln P(o \mid s)], \\ H_j &\triangleq H[P(o \mid s = j)] \\ &= -\sum_i P(o = i \mid s = j) \ln P(o = i \mid s = j), \\ H &= -\operatorname{diag}(A \cdot \ln A). \end{aligned} \tag{A.22}$$

diag 取矩阵对角元素并堆成向量. 这是第 4 章定义期望自由能时，线性代数如何简洁描述计算的例子.

[26] 译注：此非退化密度形式要求正定协方差或精确度；仅对称并不足够，退化高斯也不能直接用这里的普通逆与行列式密度.

A.3 Taylor 级数近似

A.3.1 引言

常用在点 a 附近局部有效的近似，以上帽表示，简化函数 $f(x)$. 若只关心 a，可替为该点函数值这一常数：

$$\hat{f}(x) = f(a). \tag{A.23}$$

但这只有 $x = a$ 时有效. 加入一项，使 x 的小变化引发与 a 处梯度相符的函数变化，就在紧邻区域得到近似：

$$\hat{f}(x) = f(a) + \varepsilon\, \partial_x f(x)|_{x=a}\,, \qquad \varepsilon \triangleq x - a. \tag{A.24}$$

$x = a$ 时 $\varepsilon = 0$，并且原函数与近似的一阶导数在该点相等. 继续加入梯度变化率或曲率项，可使近似对更大偏离有效；还能增加任意多项，逐阶匹配导数：

$$\begin{aligned}\hat{f}(x) &= f(a) + \varepsilon\, \partial_x f(x)|_{x=a} + \frac{1}{2}\varepsilon^2\, \partial_x^2 f(x)\big|_{x=a} + \cdots \\ &= \sum_{n=0} \frac{1}{n!}\varepsilon^n\, \partial_x^n f(x)|_{x=a}\,.\end{aligned} \tag{A.25}$$

这是 1 维展开；x 为向量时推广为

$$f(x) \approx f(a) + \varepsilon \cdot \nabla_x f(x)|_{x=a} + \frac{1}{2}\varepsilon \cdot \nabla_x (\nabla_x f(x))^T\big|_{x=a}\, \varepsilon + \cdots\,. \tag{A.26}$$

其中 $\nabla_x (\nabla_x f(x))^T$ 称为 Hessian 矩阵. 增加级数项可改进近似；本书只需二阶二次展开.[27] 以下突出其应用：支持第 4、8 章预测编码和第 9 章数据分析的 Laplace 近似，以及框 4.2 连续轨迹的运动广义坐标，后者可解释为 Taylor 系数；分别在接下两节展开.

A.3.2 Laplace 近似

概率推断的一项重要应用，是以高斯分布近似概率分布 p 在众数 μ 附近的区域. 展开对数概率，

$$\begin{aligned}\ln p(x) \approx \ln p(\mu) + \varepsilon \cdot \nabla_x \ln p(x)|_{x=\mu} + \frac{1}{2}\varepsilon \cdot \nabla_x (\nabla_x \ln p(x))^T\big|_{x=\mu}\, \varepsilon, \\ \varepsilon \triangleq x - \mu.\end{aligned} \tag{A.27}$$

这就是以 $f = \ln p$、$a = \mu$ 代入式 (A.26). 首项对 x 为常数，可吸收到归一化常数；众数处梯度为 0，第二项消失. 指数化得到

$$\begin{aligned}p(x) &\approx \frac{1}{Z} e^{-\frac{1}{2}\varepsilon \cdot C^{-1} \varepsilon} = \mathcal{N}(\mu, C^{-1}), \\ C^{-1} &\triangleq -\nabla_x (\nabla_x \ln p(x))^T\big|_{x=\mu}\,.\end{aligned} \tag{A.28}$$

[27] 译注：这些是局部展开；高阶项存在、余项控制和无穷级数收敛均需条件，增加截断阶数并非对任意函数和任意距离单调改善的无条件保证. 源式 (A.25) 未印求和上限，依源保留.

在众数附近以二次函数近似对数概率，得到高斯密度，这就是 Laplace 近似.[28] 它也可用于自由能泛函. 从第 4 章的形式出发，

$$F[q, y] = \mathbb{E}_{q(x)}[\ln q(x) - \ln p(y, x)]. \tag{A.29}$$

q 为近似后验，p 是描述隐状态 x 如何产生数据 y 的生成模型. 先展开变分密度：

$$\begin{aligned}
\ln q(x) &\approx \ln q(\mu) + (x-\mu)\cdot \underbrace{\nabla_x \ln q(x)\big|_{x=\mu}}_{0} \\
&\quad + \frac{1}{2}(x-\mu)\cdot \nabla_x (\nabla_x \ln q(x))^T\big|_{x=\mu}(x-\mu), \\
q(x) &\approx \mathcal{N}(\mu, \Sigma^{-1}), \\
\Sigma^{-1} &= -\nabla_x (\nabla_x \ln q(x))^T\big|_{x=\mu}, \qquad \mu = \arg\max_x q(x).
\end{aligned} \tag{A.30}$$

取式 (A.29) 中的期望，有

$$\begin{aligned}
\mathbb{E}_q[\ln q(x)] &\approx \ln q(\mu) - \frac{1}{2}\mathbb{E}_q[(x-\mu)\cdot\Sigma^{-1}(x-\mu)] \\
&= \ln q(\mu) - \frac{1}{2}\operatorname{tr}\left[\Sigma^{-1}\underbrace{\mathbb{E}_q[(x-\mu)(x-\mu)^T]}_{\Sigma}\right] \\
&= -\frac{k}{2}\ln 2\pi - \frac{1}{2}\ln|\Sigma| - \frac{k}{2} = -\frac{1}{2}\ln\big[(2\pi e)^k|\Sigma|\big].
\end{aligned} \tag{A.31}$$

k 是维数. 第一步用迹恒等式，第三行前两项来自多元正态密度定义. 作者称这给出 Laplace 假设下式 A.27 的第一项，第二项同样围绕 μ 展开：[29]

$$\begin{aligned}
\ln p(y, x) &\approx \ln p(y, \mu) + (\mu - x)\cdot \nabla_x \ln p(y, x)\big|_{x=\mu} \\
&\quad + \frac{1}{2}(\mu-x)\cdot \nabla_x (\nabla_x \ln p(y, x))^T\big|_{x=\mu}(\mu-x), \\
\mathbb{E}_q[\ln p(y, x)] &\approx \ln p(y, \mu) + \underbrace{(\mu - \mathbb{E}_q[x])}_{0}\cdot \nabla_x \ln p(y, x)\big|_{x=\mu} \\
&\quad + \frac{1}{2}\operatorname{tr}\left[\mathbb{E}_q[(\mu-x)(\mu-x)^T]\ \nabla_x (\nabla_x \ln p(y, x))^T\big|_{x=\mu}\right] \\
&= \ln p(y, \mu) + \frac{1}{2}\operatorname{tr}\left[\Sigma\ \nabla_x (\nabla_x \ln p(y, x))^T\big|_{x=\mu}\right].
\end{aligned} \tag{A.32}$$

最后用到正态分布均值等于众数.[30] 代回自由能，得到 Laplace 自由能：

$$\begin{aligned}
F[q, y] &\approx -\frac{1}{2}\ln\big[(2\pi e)^k|\Sigma|\big] - \ln p(y, \mu) \\
&\quad - \frac{1}{2}\operatorname{tr}\left[\Sigma\ \nabla_x (\nabla_x \ln p(y, x))^T\big|_{x=\mu}\right].
\end{aligned} \tag{A.33}$$

[28]译注：此处需要可微的内部驻点及非退化负定对数密度 Hessian，才能得到正定高斯精确度；边界众数、平坦或多峰情形不由此式自动解决.

[29]译注：源此处及下一页称式 A.27，实际所分解的是自由能式 (A.29)；原定位疑点明确保留.

[30]译注：源第一行线性项写 $\mu - x$，与标准围绕 μ 展开的 $x - \mu$ 相反，照源保留；在此高斯期望下该线性项为 0，故不影响后面所示期望式，但不能据此把展开首行视为一般正确.

x 为 1 维时，可忽略迹算子. 对后验精确度求导并令自由能导数为 0，得到[2]

$$\partial_\Sigma F[q,y]=0 \quad\Longleftrightarrow\quad \Sigma^{-1}=-\nabla_x(\nabla_x \ln p(y,x))^T\big|_{x=\mu}. \tag{A.34}$$

后验精确度是众数处状态与数据联合对数概率的负曲率. 因而不必显式优化精确度，可由后验均值解析计算. 将式 (A.34) 代入式 (A.33)，又可见依赖均值的只有数据和状态的对数概率项；连续状态空间推断细节见第 4 章.[31]

A.3.3 运动广义坐标

Taylor 近似还用于以运动广义坐标表示轨迹信念：不只推断位置 x，还推断速度 x'、加速度 x'' 及后续时间导数. 它们隐式表示可由下式明确给出的轨迹近似：

$$x(t)\approx x(\tau)+\varepsilon\, x'(t)\big|_{t=\tau}+\frac{1}{2}\varepsilon^2\, x''(t)\big|_{t=\tau}+\cdots, \qquad \varepsilon=t-\tau. \tag{A.35}$$

这也让我们计及随机涨落协方差的结构，处理自身由动力过程生成的生物涨落时很重要，第 A.5 节进一步讨论. 这里只指出，广义坐标密度相当于将坐标作为 Taylor 系数构建的局部轨迹分布.

A.4 变分法

A.4.1 泛函导数

主动推断优化信念或概率分布，常须谈论相对于函数，最小化函数的函数，即泛函，因此需要泛函或变分导数. 基本问题是找使泛函 S 最小的函数 f，通常把 S 表达为包含 f 的函数的积分[3]：

$$\phi(x)=\arg\min_f S[f(x)], \qquad S[f(x)]\triangleq\int_{x_1}^{x_2}\mathcal{L}(f(x),x)\,dx. \tag{A.36}$$

用在积分两端为 0 的任意函数 g 乘小数 u，参数化 f，对 u 求导：

$$\begin{aligned} f(x,u)&\triangleq\phi(x)+ug(x),\\ \partial_u S[f(x,u)]&=\int_{x_1}^{x_2}\partial_u\mathcal{L}(f(x,u),x)\,dx\\ &=\int_{x_1}^{x_2}\partial_u f(x,u)\partial_f\mathcal{L}(f(x,u),x)\,dx\\ &=\int_{x_1}^{x_2}g(x)\partial_f\mathcal{L}(f(x,u),x)\,dx. \end{aligned} \tag{A.37}$$

$u=0$ 时 f 是最小化函数，所以本式在该处应为 0，必要条件为

$$\int_{x_1}^{x_2}g(x)\partial_f\mathcal{L}(f(x),x)\,dx\Big|_{f=\phi}=0. \tag{A.38}$$

[31]译注：源文字说对精确度求导，实际下标 Σ 是协方差；驻点对应关系按源保留. 代入后 $\ln|\Sigma|$ 通常仍可能通过 Hessian 依赖 μ；仅有对数联合项依赖均值的说法需局部二次、固定曲率或忽略高阶导数等相应近似，不能一般无条件推出.

要对任意 g 成立，就蕴含[4]

$$\delta_f S \triangleq \partial_f \mathcal{L} = 0. \tag{A.39}$$

物理中 $\mathcal{L}$ 还可包含 f 的梯度，同样步骤产生 Euler–Lagrange 方程：

$$\delta_f S \triangleq \partial_f \mathcal{L} - \frac{d}{dx}\partial_{f'}\mathcal{L} = 0, \qquad f' \triangleq \partial_x f. \tag{A.40}$$

依据是否含梯度，式 (A.39) 或 (A.40) 表达变分导数.[32]

A.4.2 变分贝叶斯

将 f 设为近似后验的一个因子，将 S 设为自由能泛函，就较直接得到变分贝叶斯：

$$\begin{aligned} f(x) = q_i(x_i), \qquad q(x) &= \prod_i q_i(x_i), \\ \mathcal{L}(q_i(x_i), x_i) &= \int q(x)(\ln q(x) - \ln p(y,x))\, dx_{j\neq i}, \\ S[q(x)] &= F[q(x), y]. \end{aligned} \tag{A.41}$$

第二项是将后验按变量分解的平均场近似，常为计算可处理性而用，但只是诸多形式选择之一. 应用式 (A.39)，略去常数，有

$$\begin{aligned} \delta_{q_i} F[q,y] &= \ln q_i(x_i) - \int \prod_{j\neq i} q_j(x_j) \ln p(y,x)\, dx_{j\neq i}, \\ \delta_{q_i} F[q,y] = 0 \quad &\Longleftrightarrow \quad \ln q_i(x_i) = \mathbb{E}_{q_{\setminus i}}[\ln p(y,x)]. \end{aligned} \tag{A.42}$$

$\setminus i$ 指除第 i 项之外的所有因子. 本式是变分消息传递（Winn and Bishop 2005；Dauwels 2007）的核心：逐因子优化，依赖 p 相对稀疏，即不是每个 x_i 都依赖每个其他 x_j. 例如任意取

$$\begin{aligned} p(y,x) &= p(y \mid x_1)p(x_1 \mid x_2, x_3)p(x_3)p(x_2 \mid x_4)p(x_4), \\ \ln q(x_1) &= \mathbb{E}_{q(x_2)q(x_3)q(x_4)}\big[\ln p(y \mid x_1) + \ln p(x_1 \mid x_2, x_3) \\ &\qquad + \underbrace{\ln[p(x_3)p(x_2 \mid x_4)p(x_4)]}_{\text{对}x_1\text{ 为常数}}\big], \\ \ln q(x_2) &= \mathbb{E}_{q(x_1)q(x_3)q(x_4)}\big[\ln p(x_1 \mid x_2, x_3) + \ln p(x_2 \mid x_4) \\ &\qquad + \underbrace{\ln[p(y \mid x_1)p(x_3)p(x_4)]}_{\text{对}x_2\text{ 为常数}}\big]. \end{aligned} \tag{A.43}$$

这是把首行代入式 (A.42)，求 q 前两因子的结果. 略去常数，

$$\begin{aligned} \ln q(x_1) &= \ln p(y \mid x_1) + \mathbb{E}_{q(x_2)q(x_3)}[\ln p(x_1 \mid x_2, x_3)], \\ \ln q(x_2) &= \mathbb{E}_{q(x_1)q(x_3)}[\ln p(x_1 \mid x_2, x_3)] + \mathbb{E}_{q(x_4)}[\ln p(x_2 \mid x_4)]. \end{aligned} \tag{A.44}$$

[32]译注：驻点条件一般只是极小的必要条件，亦可能对应极大或鞍点；交换积分微分、使用变分基本引理等，还需相应正则性与边界条件，源此处旨在建立直觉.

期望简化用到

$$\mathbb{E}_{p(b)}[f(a)] = \int p(b)f(a)\,db = f(a)\underbrace{\int p(b)\,db}_{=1} = f(a). \tag{A.45}$$

这解释了变分消息传递的简单性：更新每个信念只需考虑少量其他信念，即关于马尔可夫毯的信念，见框 4.1.[33]

A.5 随机动力学

A.5.1 随机微分方程

本书几处涉及随机动力系统. 第 3 章强调系统长期趋向的稳态分布及其与自我证成的关系；第 4、8 章以随机微分方程构建连续状态空间模型. 主题很有趣（Yuan and Ao 2012），但定义随机过程的全部微妙之处超出范围. 简单说，随机微分方程就是增添随机项的微分方程：

$$\dot{x} = f(x) + \omega, \qquad \omega \sim \mathcal{N}(0, \tfrac{1}{2}\Gamma^{-1}). \tag{A.46}$$

随机项取均值 0 的正态分布，x 变化率最可能值为 $f(x)$. 解释有时略棘手，最好看作离散方案的极限：

$$\begin{aligned} \Delta x &= f(x)\Delta\tau + \omega(\Delta\tau)^{1/2}, \\ \Delta\tau \to 0 \quad &\Longrightarrow \quad \dot{x} = f(x) + \omega. \end{aligned} \tag{A.47}$$

若 ω 方差随 x 变化，可用多种离散化，最常见是 Itô 与 Stratonovich 解释. 本书始终假定固定方差，保证二者结果相同. 要定义第 8 章那类生成模型，只需描述变化率的分布：

$$p(\dot{x} \mid x) = \mathcal{N}(f(x), \tfrac{1}{2}\Gamma^{-1}). \tag{A.48}$$

这概括确定性与随机动力系统的区别：前者知道 x 就知道速度，后者知道 x 只知道可能速度的分布.[34]

A.5.2 非平衡稳态

第 3 章说，沿能量或惊异函数下降的系统可保持形态，持续处于可能非平衡的稳态. 这里从稳态出发恢复惊异最小化或“自我证成”动力学（Hohwy 2016）. 起点是随机动力学的另一表达：描述概率密度随时间变化的确定性偏微分方程，即 Fokker–Planck 方程（Risken 1996），

$$\partial_\tau p(x) = \nabla_x \cdot \big(\Gamma \nabla_x p(x) - f(x)p(x)\big). \tag{A.49}$$

[33]译注：本节依源反复略去与当前变量无关的常数，完整归一化更新为 $\ln q_i = \mathbb{E}_{q_{\setminus i}} \ln p +$ 常数；各密度须归一化、相关期望须存在，坐标最优化不自动保证全局最优.

[34]译注：依全书高斯第二参数为精确度的约定，此处噪声协方差为 2Γ，与后面 Fokker–Planck 扩散系数相应. 若将离散极限理解为白噪声驱动扩散，其样本轨迹通常无经典瞬时导数，式 (A.46)、(A.48) 是作者形式记法，不能直接当普通有限方差瞬时速度密度；平滑有色噪声的广义坐标则须另具时间正则性.

令密度时间偏导为 0，定义稳态：

$$\begin{aligned} \partial_\tau p(x) = 0 \quad &\Longrightarrow \quad \nabla_x \cdot (\Gamma \nabla_x p(x) - f(x)p(x)) = 0 \\ &\Longrightarrow \quad f(x) = -(\Gamma - Q(x))\nabla_x \mathfrak{I}(x), \\ \nabla_x \cdot (Q(x)\nabla_x p(x)) = 0, \quad &\mathfrak{I}(x) \triangleq -\ln p(x). \end{aligned} \tag{A.50}$$

第三个等式[5]是关键，作者说它表明保持稳态的系统必须展示平均而言最小化惊异的动力学. Q 允许沿惊异等高线运动，不增不减惊异. 这是自我证成观点与有感知系统物理学的核心；更全面讨论见 Friston（2019a）.[35]

A.5.3 运动广义坐标

第 A.3.3 节用时间 Taylor 系数表示短轨迹. 随机场景中，各阶广义运动的协方差如何计入？Cox and Miller（1965）给出答案，这里概述. 用流、流的变化率及后续导数的随机涨落向量表示随机过程：

$$\begin{aligned} \dot{\tilde{x}} &= \tilde{f}(\tilde{x}) + \tilde{\omega}, \\ \tilde{\omega} \triangleq \begin{bmatrix} \omega \\ \omega' \\ \omega'' \\ \omega''' \\ \vdots \end{bmatrix} &= \begin{bmatrix} \omega^{[0]} \\ \omega^{[1]} \\ \omega^{[2]} \\ \omega^{[3]} \\ \vdots \end{bmatrix}. \end{aligned} \tag{A.51}$$

随机涨落刻画为

$$\begin{aligned} p(\tilde{\omega}) = \mathcal{N}(0, \tilde{\Pi}), \qquad \mathbb{E}[\omega^{[0]}(\tau)] = 0, \\ \mathbb{E}[\omega^{[0]}(\tau) \cdot \omega^{[0]}(\tau)] = \Sigma. \end{aligned} \tag{A.52}$$

自相关函数为

$$\rho(h) \triangleq \Sigma^{-1} \underbrace{\mathbb{E}[\omega^{[0]}(\tau) \cdot \omega^{[0]}(\tau + h)]}_{\text{协方差}}. \tag{A.53}$$

两边乘方差，可见两时刻噪声协方差分解为自相关与方差. 第 i 阶导数定义为以下差分的极限：

$$\omega^{[i]}(\tau, \Delta\tau) = \frac{\omega^{[i-1]}(\tau + \Delta\tau) - \omega^{[i-1]}(\tau)}{\Delta\tau}. \tag{A.54}$$

由前式可表达变量与其一阶导数的协方差：

$$\begin{aligned} \mathbb{E}[\omega^{[1]}(\tau, \Delta\tau) \cdot \omega^{[0]}(\tau + h)] &= \frac{1}{\Delta\tau}\mathbb{E}[(\omega^{[0]}(\tau + \Delta\tau) - \omega^{[0]}(\tau))\omega^{[0]}(\tau + h)] \\ &= \frac{1}{\Delta\tau}\Sigma(\rho(h - \Delta\tau) - \rho(h)). \end{aligned} \tag{A.55}$$

[35]译注：从一般稳态散度方程得到所写局域 Q 分解，还需相关存在性、边界、正则性及 Q 的结构条件；沿等高线的解释通常还用反对称性等条件. 保留源方程和作者结论，不将其升级为任意稳态系统的无条件表示定理.

令时间增量趋于 0，

$$\mathbb{E}[\omega^{[1]}(\tau)\cdot\omega^{[0]}(\tau+h)]=\Sigma\dot{\rho}(h). \tag{A.56}$$

译注：源式 (A.56) 写正号，但由前一式差商直接取极限得到 $-\Sigma\dot{\rho}(h)$；保留原式，不静默改号. 在 $h=0$ 处自相关达到最大、导数为 0，所以作者关于瞬时位置与速度正交、协方差为 0 的后续结论不受此处符号影响；这仍依赖所用平稳可微过程假设.

再进一步求一阶导数方差：

$$\begin{aligned}
&\mathbb{E}[\omega^{[1]}(\tau,\Delta\tau)\cdot\omega^{[1]}(\tau+h,\Delta\tau)]\\
&\quad=\frac{1}{\Delta\tau^2}\Sigma\mathbb{E}\big[(\omega^{[0]}(\tau+\Delta\tau)-\omega^{[0]}(\tau))(\omega^{[0]}(\tau+h+\Delta\tau)-\omega^{[0]}(\tau+h))\big]\\
&\quad=\Sigma\frac{1}{\Delta\tau}\left[\frac{\rho(h)-\rho(h-\Delta\tau)}{\Delta\tau}-\frac{\rho(h+\Delta\tau)-\rho(h)}{\Delta\tau}\right].
\end{aligned} \tag{A.57}$$

译注：源首个期望式前还额外有 Σ 因子，按源保留；若 $\omega^{[0]}$ 已具有式 (A.52) 的方差，通常该期望前不应再次乘方差，否则量纲及与末行的对应有疑点.

令 $\Delta\tau\to 0$，

$$\mathbb{E}[\omega^{[1]}(\tau)\cdot\omega^{[1]}(\tau+h)]=-\Sigma\ddot{\rho}(h). \tag{A.58}$$

继续到后续导数，可计算广义精确度矩阵：

$$\tilde{\Pi}=\Sigma^{-1}\otimes\begin{bmatrix}1 & 0 & \ddot{\rho}(0) & \\ 0 & -\ddot{\rho}(0) & 0 & \\ \ddot{\rho}(0) & 0 & \dddot{\rho}(0) & \\ & & & \ddots\end{bmatrix}^{-1}. \tag{A.59}$$

取高斯自相关，

$$\begin{aligned}
\rho(h)&=e^{-\frac{1}{2}\lambda h^2}, & \rho(0)&=1,\\
\dot{\rho}(h)&=-\lambda\rho(h), & \dot{\rho}(0)&=0,\\
\ddot{\rho}(h)&=\lambda(\lambda h^2-1)\rho(h), & \ddot{\rho}(0)&=-\lambda,\\
\dddot{\rho}(h)&=\lambda^2 h(\lambda h^2-3)\rho(h), & \dddot{\rho}(0)&=0,\\
\ddddot{\rho}(h)&=\lambda^2(\lambda^2h^4-6\lambda h^2+3)\rho(h), & \ddddot{\rho}(0)&=3\lambda^2.
\end{aligned} \tag{A.60}$$

译注：源第一导数漏 h，且第三导数与对首行直接微分的符号相反；本式依原 PDF242 书页保留. 直接求导应为 $\dot{\rho}=-\lambda h\rho$、$\dddot{\rho}=\lambda^2 h(3-\lambda h^2)\rho$；右列各原点值与首行直接求导一致，故式 (A.59) 所用原点偶数阶值未因这两处而改变.

精确度项 λ 可看作涨落平滑性的参数，也可通过最小化自由能、结合数据优化.

Appendix B

主动推断的方程

B.1 引言

本附录给出主动推断的数学概要，补充正文方程的来源细节，填入部分略去的中间步骤. 它直接建立在附录 A 章的背景上，处理部分可观测马尔可夫决策过程 POMDP 与预测编码架构中的推断，并涉及正文所提的结构学习和模型约简. 力求相对自足，特别关注常令人困惑的主题. 不必理解本附录全部细节，仍可有效应用主动推断；这里主要面向希望了解技术细节的读者.

B.2 马尔可夫决策过程

B.2.1 状态推断

求解 POMDP，目的是选择适当行动路线或策略. 主动推断将其表述为推断备选策略的后验，需要策略先验，见第 B.2.2 节，以及给定策略后观测的似然；本节关注后者. 其计算并不直接，因为策略 π 影响状态 s 的轨迹，以波浪号表示，状态又影响结果 o，策略不直接影响结果. 所以要对状态轨迹求和、边缘化，得到

$$P(\tilde{o} \mid \pi) = \sum_{\tilde{s}} P(\tilde{o} \mid \tilde{s}) P(\tilde{s} \mid \pi). \tag{B.1}$$

非平凡状态空间中，此求和可能很困难. 可用第 2 章的自由能泛函近似；它是近似后验 Q 和生成模型 P 的泛函，

$$\begin{aligned} F(\pi) &= \mathbb{E}_{Q(\tilde{s}|\pi)}[\ln Q(\tilde{s} \mid \pi) - \ln P(\tilde{o}, \tilde{s} \mid \pi)] \geq -\ln P(\tilde{o} \mid \pi), \\ Q(\tilde{s} \mid \pi) &= \arg\min_{Q} F(\pi) \quad \Longrightarrow \quad F(\pi) \approx -\ln P(\tilde{o} \mid \pi). \end{aligned} \tag{B.2}$$

要推断做什么，必须近似策略的边缘似然；要取得好近似，须先优化该策略下的状态信念，所以规划要求先进行知觉推断. 实践中，采用第 A.4.2 节的方法，选择明确分布形式，

$$\begin{aligned} Q(\tilde{s} \mid \pi) &= \prod_{\tau} Q(s_\tau \mid \pi), & Q(s_\tau \mid \pi) &= \mathrm{Cat}(\mathbf{s}_{\pi\tau}), \\ P(\tilde{o} \mid \tilde{s}) &= \prod_{\tau} P(o_\tau \mid s_\tau), & P(o_\tau \mid s_\tau) &= \mathrm{Cat}(A), \\ P(\tilde{s} \mid \pi) &= P(s_1) \prod_{\tau} P(s_{\tau+1} \mid s_\tau, \pi), & P(s_{\tau+1} \mid s_\tau, \pi) &= \mathrm{Cat}(B_{\pi\tau}), \\ & & P(s_1) &= \mathrm{Cat}(D). \end{aligned} \tag{B.3}$$

首行按时间因子分解，作平均场近似，各时间点的策略条件状态信念，由概率向量 $\mathbf{s}_{\pi\tau}$ 给出. 第二行通过矩阵，或状态再分解时的张量 A，给出各状态的观测分布. 先验状态轨迹由策略下转移 $B_{\pi\tau}$ 和初始状态概率 D 构成. 代入得到

$$\begin{aligned}\mathbf{F}_\pi &= \mathbf{s}_{\pi 1}\cdot(\ln \mathbf{s}_{\pi 1} - \ln A\cdot \mathbf{o}_1 - \ln D)\\ &\quad + \sum_{\tau=2}\mathbf{s}_{\pi\tau}\cdot(\ln \mathbf{s}_{\pi\tau} - \ln A\cdot \mathbf{o}_\tau - \ln B_{\pi\tau}\mathbf{s}_{\pi,\tau-1}).\end{aligned} \tag{B.4}$$

概率向量与另一量的点积，相当于取期望，见第 A.2.1 节. 结果也当作概率向量，但实际观测对应分量为 1，其他为 0，即独热或 1-in-k 编码. 现在须对状态信念最小化自由能，使之成为边缘似然的好近似. 可如变分贝叶斯逐因子迭代至收敛；为追求生物合理方案，也可构造收敛到相同解的动力系统，沿自由能梯度下降至极小.

对当前信念求梯度，再用代表对数后验的辅助变量 $\mathbf{v}$ 作梯度下降，经 softmax 归一化指数函数[1]转换为概率分布，

$$\begin{aligned}\mathbf{s}_{\pi\tau} &= \sigma(\mathbf{v}_{\pi\tau}), \qquad \dot{\mathbf{v}}_{\pi\tau} = -\nabla_{\mathbf{s}_{\pi\tau}}\mathbf{F}_\pi,\\ \nabla_{\mathbf{s}_{\pi\tau}}\mathbf{F}_\pi &= \ln \mathbf{s}_{\pi\tau} - \ln A\cdot\mathbf{o}_\tau - \ln B_{\pi\tau}\mathbf{s}_{\pi,\tau-1} - \ln B_{\pi,\tau+1}\cdot\mathbf{s}_{\pi,\tau+1}.\end{aligned} \tag{B.5}$$

与式 (A.42) 的变分消息传递有相同解，只用局部感觉数据及紧邻过去、未来信念，高效计算后验. 但按时间平均场分解常导致过度确信. 实践中可用修正的边缘消息传递 (Friston, FitzGerald et al. 2017；Parr, Markovic et al. 2019)，

$$\begin{aligned}\dot{\mathbf{v}}_{\pi\tau} &= \boldsymbol{\varepsilon}_{\pi\tau},\\ \boldsymbol{\varepsilon}_{\pi\tau} &= \ln A\cdot\mathbf{o}_\tau + \frac{1}{2}\left[\ln(B_{\pi\tau}\mathbf{s}_{\pi,\tau-1}) + \ln(B^\dagger_{\pi,\tau+1}\mathbf{s}_{\pi,\tau+1})\right] - \ln \mathbf{s}_{\pi\tau},\\ B^\dagger_{\pi\tau} &\propto B^T_{\pi\tau}.\end{aligned} \tag{B.6}$$

这产生更保守、更不确定的后验. 其他方案包括 Bethe 近似 (Schwöbel et al. 2018)；但本书写作时最常用实现采用边缘消息传递.[36]

B.2.2 规划即推断

上一节求策略条件状态信念，最小化条件自由能. 每个策略视为模型，该自由能扮演负对数边缘似然或模型证据. 加上策略先验与后验，可写

$$\begin{aligned}F &= \mathbb{E}_{Q(\pi)}[\ln Q(\pi) - \ln P(\pi,\tilde{o})]\\ &\approx \mathbb{E}_{Q(\pi)}[\ln Q(\pi) + F(\pi) - \ln P(\pi)],\\ P(\pi) &= \mathrm{Cat}(\boldsymbol{\pi}_0), \qquad Q(\pi) = \mathrm{Cat}(\boldsymbol{\pi}),\\ \boldsymbol{\pi}_0 &= \sigma(\ln E - \mathbf{G}).\end{aligned} \tag{B.7}$$

[36]译注：这些更新的非负归一化、零概率的对数、初末时间边界与固定点收敛均需相应实现约定. 源 $B_{\pi\tau}$ 在式 (B.3) 转移下标与式 (B.4) 的当前步用法存在一位索引疑点，按源保留；式 (B.5) 也沿源略去概率单纯形约束下可吸收的常数，不由梯度下降形式保证非凸问题的唯一全局最小.

近似等号来自式 (B.2). E 是固定策略信念向量，可看作偏差或习惯项，$\mathbf{G}$ 是各策略期望自由能. 用充分统计量表达，

$$F = \boldsymbol{\pi} \cdot (\ln \boldsymbol{\pi} - \ln E + \mathbf{F} + \mathbf{G}). \tag{B.8}$$

$\mathbf{F}$ 的分量是式 (B.4) 的 $\mathbf{F}_\pi$. 求梯度得策略信念的最优更新，即规划：

$$\nabla_{\boldsymbol{\pi}} F = 0 \quad \Longleftrightarrow \quad \boldsymbol{\pi} = \sigma(\ln E - \mathbf{F} - \mathbf{G}). \tag{B.9}$$

B.2.3 学习

学习须为生成模型分布参数配先验. 因为它们用范畴分布表达，适当共轭先验是 Dirichlet 分布. 以初始状态先验为例，依赖期望对数先验的自由能项为

$$\begin{aligned} F &= \cdots + D_{\mathrm{KL}}[Q(D) \| P(D)] - \mathbb{E}_{Q(s_1)Q(D)}[\ln P(s_1 \mid D)] \\ &= \cdots + (\mathbf{d} - d) \cdot \mathbb{E}_{Q(D)}[\ln D] - \mathbf{s}_1 \cdot \mathbb{E}_{Q(D)}[\ln D], \\ \mathbb{E}_{Q(D)}[\ln D] &= \psi(\mathbf{d}) - \psi(\mathbf{d}_0), \qquad \mathbf{d}_0 = \sum_i \mathbf{d}_i, \\ Q(D) &\triangleq \mathrm{Dir}(\mathbf{d}), \qquad P(D) \triangleq \mathrm{Dir}(d). \end{aligned} \tag{B.10}$$

第三行是有用恒等式：Dirichlet 变量的期望对数，是两个 digamma 函数 ψ 的差. 作者称 digamma 为 Gamma 函数的导数.[37] 由此求极小，

$$\nabla_{\mathbb{E}[\ln D]} F = \mathbf{d} - d - \mathbf{s}_1 = 0 \quad \Longleftrightarrow \quad \mathbf{d} = d + \mathbf{s}_1. \tag{B.11}$$

这给出从先验 Dirichlet 参数更新至后验的简单方案. 其他模型分布也有类似规则：

$$\begin{aligned} \mathbf{a} &= a + \sum_\tau \mathbf{o}_\tau \otimes \mathbf{s}_\tau, \\ \mathbf{b}_{\pi\tau} &= b_{\pi\tau} + \sum_\tau \mathbf{s}_{\pi\tau} \otimes \mathbf{s}_{\pi,\tau-1}, \\ \mathbf{c} &= c + \sum_\tau \mathbf{o}_\tau, \qquad \mathbf{d} = d + \mathbf{s}_1, \qquad \mathbf{e} = e + \boldsymbol{\pi}. \end{aligned} \tag{B.12}$$

即被相应分布项预测的事情发生时，条件概率中可能是一对事情的组合，就增加该概率数组元素，表示以后更可能再次发生.[38]

B.2.4 精确度

有时可稍改参数化，例如 Gibbs 测度，为概率分布加扮演精确度的逆温度. 最常见的是策略精确度 γ，

$$P(\pi \mid \gamma) = \mathrm{Cat}(\boldsymbol{\pi}_0), \qquad \boldsymbol{\pi}_0 = \sigma(-\gamma \mathbf{G}). \tag{B.13}$$

[37]译注：标准定义为对数 Gamma 函数的导数，$\psi(x) = \frac{d}{dx} \ln \Gamma(x)$；源文字表述与后面式 (B.33) 所用恒等式不同，保留并注明，不改正确公式.

[38]译注：源第二行同时将 τ 用于左侧分量及右侧求和下标，作用范围并不明确，原样保留，不自行更改共享转移参数或策略加权约定.

为简单起见，本节略去 E. 还考虑似然精确度 ζ 与转移精确度 ω；其先验假定为 Gamma 分布，

$$\begin{aligned} P(\zeta) &\propto \beta_\zeta \exp(-\beta_\zeta \zeta), \\ P(\omega) &\propto \beta_\omega \exp(-\beta_\omega \omega), \\ P(\gamma) &\propto \beta_\gamma \exp(-\beta_\gamma \gamma). \end{aligned} \tag{B.14}$$

近似后验同为 Gamma 形式，以下用粗体 $\boldsymbol{\beta}$ 超参数区别后验与先验充分统计量. 此参数化下，

$$\begin{aligned} \boldsymbol{\zeta} &= \mathbb{E}_{Q(\zeta)}[\zeta] = \boldsymbol{\beta}_\zeta^{-1}, \\ \boldsymbol{\omega} &= \mathbb{E}_{Q(\omega)}[\omega] = \boldsymbol{\beta}_\omega^{-1}, \\ \boldsymbol{\gamma} &= \mathbb{E}_{Q(\gamma)}[\gamma] = \boldsymbol{\beta}_\gamma^{-1}. \end{aligned} \tag{B.15}$$

译注：所写密度是正支撑上形状参数为 1、以率参数表示的 Gamma 特例，即指数分布，均值为率的倒数；非任意 Gamma 形状都可直接使用该均值式.

变分自由能为

$$\begin{aligned} F = \mathbb{E}_Q\big[F(\pi, \zeta, \omega) + D_{\mathrm{KL}}[Q(\pi) \| P(\pi \mid \gamma)]\big] \\ + D_{\mathrm{KL}}[Q(\gamma) \| P(\gamma)] + D_{\mathrm{KL}}[Q(\omega) \| P(\omega)] + D_{\mathrm{KL}}[Q(\zeta) \| P(\zeta)]. \end{aligned} \tag{B.16}$$

略常数，以充分统计量表示，

$$\begin{aligned} F &= \boldsymbol{\pi} \cdot (\mathbf{F} + \ln \boldsymbol{\pi} + \boldsymbol{\gamma} \cdot \mathbf{G} + \ln Z(\boldsymbol{\gamma})) \\ &\quad + \ln \boldsymbol{\beta}_\gamma + \ln \boldsymbol{\beta}_\omega + \ln \boldsymbol{\beta}_\zeta - \ln \beta_\gamma - \ln \beta_\omega - \ln \beta_\zeta \\ &\quad + \boldsymbol{\gamma} \beta_\gamma + \boldsymbol{\omega} \beta_\omega + \boldsymbol{\zeta} \beta_\zeta, \\ \mathbf{F}_\pi &\approx -\sum_\tau \mathbf{s}_{\pi\tau} \cdot \big(\boldsymbol{\zeta} \ln A \cdot \mathbf{o}_\tau + \boldsymbol{\omega} \ln B_{\pi\tau} \mathbf{s}_{\pi,\tau-1} \\ &\qquad\qquad - \ln Z(\boldsymbol{\zeta}) \cdot \mathbf{o}_\tau - \ln Z(\boldsymbol{\omega}) \mathbf{s}_{\pi,\tau-1}\big). \end{aligned} \tag{B.17}$$

Z 是配分函数或归一化常数，

$$\begin{aligned} Z(\boldsymbol{\zeta})_j &= \sum_i (A_{ij})^{\boldsymbol{\zeta}}, \qquad Z(\boldsymbol{\omega})_j = \sum_i ((B_{\pi\tau})_{ij})^{\boldsymbol{\omega}}, \\ Z(\boldsymbol{\gamma}) &= \sum_\pi \exp(-\boldsymbol{\gamma} \mathbf{G}_\pi), \\ \partial_\zeta \ln Z(\boldsymbol{\zeta}) \mathbf{s}_\tau &= \mathbf{o}_\tau^\zeta \cdot \ln A, \\ \partial_\omega \ln Z(\boldsymbol{\omega}) \mathbf{s}_{\pi,\tau-1} &= \mathbf{s}_{\pi\tau}^\omega \cdot \ln B_\pi, \\ \partial_\gamma \ln Z(\boldsymbol{\gamma}) &= -\boldsymbol{\pi}_0 \cdot \mathbf{G}, \\ \mathbf{o}_\tau^\zeta &\triangleq \sigma(\boldsymbol{\zeta} \ln A) \mathbf{s}_\tau, \qquad \mathbf{s}_{\pi\tau}^\omega \triangleq \sigma(\boldsymbol{\omega} \ln B_{\pi\tau}) \mathbf{s}_{\pi,\tau-1}, \\ \boldsymbol{\pi}_0 &\triangleq \sigma(-\boldsymbol{\gamma} \mathbf{G}). \end{aligned} \tag{B.18}$$

对期望精确度取偏导[2]，

$$\begin{Bmatrix} \partial_\zeta F \\ \partial_\omega F \\ \partial_\gamma F \end{Bmatrix} = 0 \quad \Longleftrightarrow \quad \begin{Bmatrix} \boldsymbol{\beta}_\zeta \\ \boldsymbol{\beta}_\omega \\ \boldsymbol{\beta}_\gamma \end{Bmatrix} = \begin{Bmatrix} \sum_\tau (\mathbf{o}_\tau^\zeta - \mathbf{o}_\tau) \cdot \ln A + \beta_\zeta \\ \sum_\tau \boldsymbol{\pi} \cdot (\mathbf{s}_{\pi\tau}^\omega - \mathbf{s}_{\pi\tau}) \cdot \ln B_\pi \mathbf{s}_{\pi,\tau-1} + \beta_\omega \\ (\boldsymbol{\pi} - \boldsymbol{\pi}_0) \cdot \mathbf{G} + \beta_\gamma \end{Bmatrix}. \tag{B.19}$$

写成生物上合理的梯度下降，

$$\begin{Bmatrix} \dot{\boldsymbol{\beta}}_\zeta \\ \dot{\boldsymbol{\beta}}_\omega \\ \dot{\boldsymbol{\beta}}_\gamma \end{Bmatrix} = \begin{Bmatrix} \sum_\tau (\mathbf{o}_\tau^\zeta - \mathbf{o}_\tau) \cdot \ln A + \beta_\zeta - \boldsymbol{\beta}_\zeta \\ \sum_\tau \boldsymbol{\pi} \cdot (\mathbf{s}_{\pi\tau}^\omega - \mathbf{s}_{\pi\tau}) \cdot \ln B_\pi \mathbf{s}_{\pi,\tau-1} + \beta_\omega - \boldsymbol{\beta}_\omega \\ (\boldsymbol{\pi} - \boldsymbol{\pi}_0) \cdot \mathbf{G} + \beta_\gamma - \boldsymbol{\beta}_\gamma \end{Bmatrix}. \tag{B.20}$$

维数意味着 A 的精确度为行向量，每个状态，即每列 A，有自己的精确度参数.[39]

B.2.5 期望自由能

正文已广泛讨论期望自由能，这里补充两点：为何用它定义策略先验的当时理解，以及计算实现细节. 第 7 章等数值模拟已说明其用途，但为何有用仍是活跃研究主题，解释还会演变. 以下概述本书写作时最简约的解释（Da Costa et al. 2020；Friston, Da Costa et al. 2020）. 起点是规定系统在未来时刻 τ 达到某稳态，或满足此处以潜状态定义的偏好，

$$Q(s_\tau) = \mathbb{E}_{Q(\pi)}[Q(s_\tau \mid \pi)] = P(s_\tau \mid C). \tag{B.21}$$

须找满足它的 $Q(\pi)$. 本式蕴含

$$\begin{aligned} D_{\mathrm{KL}}[Q(\pi \mid s_\tau)Q(s_\tau) \| Q(\pi \mid s_\tau)P(s_\tau \mid C)] = 0, \\ \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi, s_\tau)] = \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi \mid s_\tau) + \ln P(s_\tau \mid C)]. \end{aligned} \tag{B.22}$$

分解左侧，隔离关注的策略项，

$$\mathbb{E}_{Q(\pi)}[\ln Q(\pi)] = \mathbb{E}_{Q(\pi,s_\tau)}[\ln Q(\pi \mid s_\tau) + \ln P(s_\tau \mid C) - \ln Q(s_\tau \mid \pi)]. \tag{B.23}$$

定义两个熵之比，

$$\alpha = \frac{\mathbb{E}_{Q(s_\tau)}[H[Q(\pi \mid s_\tau)]]}{\mathbb{E}_{Q(s_\tau,\pi)}[H[P(o_\tau \mid s_\tau)]]}. \tag{B.24}$$

直观上，它表达给定状态下合理行为输出或策略的范围，与该状态预期结果范围之比. 很大时，世界虽生成精确感觉观测，行为却与世界状态关系不大；很小时，生物知道状态后总同样行动，却很少获得精确数据. 这里规定研究 $\alpha = 1$、与世界交换相对平衡对称的系统，使两熵相等. 返回前式，

$$\begin{aligned} \mathbb{E}_{Q(\pi)}[\ln Q(\pi)] &= -\mathbb{E}_{Q(s_\tau)}[H[Q(\pi \mid s_\tau)]] + \mathbb{E}_{Q(\pi,s_\tau)}[\ln P(s_\tau \mid C) - \ln Q(s_\tau \mid \pi)] \\ &= -\mathbb{E}_{Q(s_\tau,\pi)}[H[P(o_\tau \mid s_\tau)]] - \mathbb{E}_{Q(\pi)}[D_{\mathrm{KL}}[Q(s_\tau \mid \pi) \| P(s_\tau \mid C)]]. \end{aligned} \tag{B.25}$$

[39]译注：本组式沿源保留压缩张量和点积记法、列归一化及粗体后验区别；例如式 (B.18) 的分量指数与式 (B.19) 涉及状态加权的缩并，需按实际实现核对维数，不能只凭形式梯度认定任意数组都定义同一标量目标.

第二行由 $\alpha = 1$ 而来. 作者接着说，选择下式即可满足本式，因而也满足式 (B.21)：

$$\ln Q(\pi) = -\underbrace{\mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]]}_{\text{期望模糊度}} - \underbrace{D_{\mathrm{KL}}[Q(s_\tau \mid \pi) \| P(s_\tau \mid C)]}_{\text{风险}}. \tag{B.26}$$

译注：源从整体期望恒等式转到逐策略对数概率，未显式给出归一化常数，且 $\alpha = 1$ 是额外规定；要由此构造满足目标边缘分布的概率解，还需可实现性与自洽条件. 保留源式与推论措辞，不将其视为对任意策略条件分布都已证明的充分解；式 (B.24) 在分母为 0 等情形也须另行处理.

最后把右侧与将偏好定义在观测上的期望自由能联系起来：

$$\begin{aligned}
&\mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] + D_{\mathrm{KL}}[Q(s_\tau \mid \pi) \| P(s_\tau \mid C)] \\
&\quad = \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] + D_{\mathrm{KL}}[Q(s_\tau \mid \pi) \| P(s_\tau \mid C)] \\
&\qquad + \underbrace{\mathbb{E}_{Q(s_\tau|\pi)P(o_\tau|s_\tau)}[\ln P(o_\tau \mid s_\tau)] - \mathbb{E}_{Q(s_\tau|\pi)P(o_\tau|s_\tau)}[\ln P(o_\tau \mid s_\tau)]}_{=0} \\
&\quad = \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] + D_{\mathrm{KL}}[Q(o_\tau, s_\tau \mid \pi) \| P(o_\tau, s_\tau \mid C)] \\
&\quad = \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] + D_{\mathrm{KL}}[Q(o_\tau \mid \pi) \| P(o_\tau \mid C)] \\
&\qquad + \mathbb{E}_{Q(o_\tau|\pi)}[D_{\mathrm{KL}}[Q(s_\tau \mid o_\tau, \pi) \| P(s_\tau \mid o_\tau, C)]] \\
&\quad \geq \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] + D_{\mathrm{KL}}[Q(o_\tau \mid \pi) \| P(o_\tau \mid C)] = G(\pi).
\end{aligned} \tag{B.27}$$

作者因经验上读者常难理解此结果，故略显繁琐地列出步骤. 最后一行略去非负 KL 项产生不等式；关键是式 (B.26) 中最可能策略所最小化的模糊度与风险，是全书期望自由能的上界.[40]

计算实现可用附录 A.2 的线性代数. 先验概率向量 C 表示偏好时，实用项为

$$\begin{aligned}
\mathbb{E}_{Q(o_\tau|\pi)}[\ln P(o_\tau \mid C)] &= \mathbf{o}_{\pi\tau} \cdot \ln C_\tau, \\
Q(o_\tau \mid \pi) = \mathrm{Cat}(\mathbf{o}_{\pi\tau}), \qquad \mathbf{o}_{\pi\tau} &= A\mathbf{s}_{\pi\tau}.
\end{aligned} \tag{B.28}$$

隐状态信息增益，即显著性、认知价值或贝叶斯惊异，是两熵之差：

$$\begin{aligned}
H[Q(o_\tau \mid \pi)] - \mathbb{E}_{Q(s_\tau|\pi)}[H[P(o_\tau \mid s_\tau)]] &= -\mathbf{o}_\pi \cdot \ln \mathbf{o}_\pi - H \cdot \mathbf{s}_{\pi\tau}, \\
H &\triangleq -\operatorname{diag}(A \cdot \ln A).
\end{aligned} \tag{B.29}$$

最后一行见第 A.2.3 节. 结合实用项得到

$$\mathbf{G}_\pi = \sum_\tau \mathbf{G}_{\pi\tau}, \qquad \mathbf{G}_{\pi\tau} = H \cdot \mathbf{s}_{\pi\tau} + \mathbf{o}_{\pi\tau} \cdot (\ln \mathbf{o}_{\pi\tau} - \ln C_\tau). \tag{B.30}$$

主动学习还需补充参数信息增益，即新奇性. 用两个 Dirichlet 分布的 KL，给定状态—

[40] 译注：联合 KL 改写使用 $Q(o, s \mid \pi) = P(o \mid s)Q(s \mid \pi)$ 与相同似然下的 $P(o, s \mid C) = P(o \mid s)P(s \mid C)$，以及所需支撑和有限性条件；界不能一般改写成等号.

结果组合后的增益为

$$
\begin{aligned}
W_{ij} &\triangleq D_{\mathrm{KL}}[P(A_{ij} \mid o=i, s=j) \| P(A_{ij})] \\
&= \underbrace{\ln \Gamma(a_{ij}) - \ln \Gamma(a_{ij}+1)}_{-\ln a_{ij}} + \underbrace{\ln \Gamma(a_{0j}+1) - \ln \Gamma(a_{0j})}_{+\ln a_{0j}} \\
&\quad + \psi(a_{ij}+1) - \psi(a_{0j}+1), \qquad a_{0j} \triangleq \sum_i a_{ij}.
\end{aligned} \tag{B.31}
$$

知道该组合发生后，相应 Dirichlet 参数加 1；用括号所示对数 Gamma 恒等式简化，

$$
\begin{aligned}
W_{ij} &= \ln \frac{a_{0j}}{a_{ij}} + \frac{\partial_{a_{ij}} \Gamma(a_{ij}+1)}{a_{ij}\Gamma(a_{ij})} - \frac{\partial_{a_{0j}} \Gamma(a_{0j}+1)}{a_{0j}\Gamma(a_{0j})} \\
&= \ln \frac{a_{0j}}{a_{ij}} + \frac{1}{a_{ij}} + \frac{\partial_{a_{ij}} \Gamma(a_{ij})}{\Gamma(a_{ij})} - \frac{1}{a_{0j}} - \frac{\partial_{a_{0j}} \Gamma(a_{0j})}{\Gamma(a_{0j})}.
\end{aligned} \tag{B.32}
$$

这里用 $x\Gamma(x) = \Gamma(x+1)$ 及乘积求导，再用 $\psi(x)\Gamma(x) = \partial_x \Gamma(x)$ 与 $\psi(x) \approx \ln x - (2x)^{-1}$，

$$
\begin{aligned}
W_{ij} &= \frac{1}{a_{ij}} - \frac{1}{a_{0j}} + \ln \frac{a_{0j}}{a_{ij}} + \psi(a_{ij}) - \psi(a_{0j}) \\
&\approx \frac{1}{2a_{ij}} - \frac{1}{2a_{0j}}.
\end{aligned} \tag{B.33}
$$

期望信息增益为

$$
\mathbb{E}_{Q(o_\tau, s_\tau \mid \pi)}[D_{\mathrm{KL}}[P(A \mid o_\tau, s_\tau) \| P(A)]] \approx \mathbf{o}_{\pi\tau} \cdot W \mathbf{s}_{\pi\tau}. \tag{B.34}
$$

将它补入期望自由能，便在实用与显著选择外产生新奇寻求.[41]

B.2.6 贝叶斯模型约简

第 7 章简述结构学习和模型约简，这里再展开. 贝叶斯模型约简比较只在先验上不同的模型. 用贝叶斯定理，可将两个模型的数据与参数联合概率之比写为

$$
\frac{P(y,\theta)}{\widetilde{P}(y,\theta)} = \frac{P(y \mid \theta)P(\theta)}{\widetilde{P}(y \mid \theta)\widetilde{P}(\theta)} = \frac{P(\theta \mid y)P(y)}{\widetilde{P}(\theta \mid y)\widetilde{P}(y)}. \tag{B.35}
$$

若似然相同，就可消去相应项，重排得到约简先验下的后验，

$$
\widetilde{P}(\theta \mid y) = \frac{P(\theta \mid y)P(y)\widetilde{P}(\theta)}{\widetilde{P}(y)P(\theta)}. \tag{B.36}
$$

两边对参数积分，

$$
\begin{aligned}
1 &= \frac{P(y)}{\widetilde{P}(y)} \mathbb{E}_{P(\theta \mid y)} \left[\frac{\widetilde{P}(\theta)}{P(\theta)} \right], \\
\ln \widetilde{P}(y) &= \ln P(y) + \ln \mathbb{E}_{P(\theta \mid y)} \left[\frac{\widetilde{P}(\theta)}{P(\theta)} \right].
\end{aligned} \tag{B.37}
$$

[41] 译注：源 $P(A_{ij})$ 以单元素记号指代 Dirichlet 参数更新；Dirichlet 的随机对象实际是归一化列向量，单元素边缘通常为 Beta 分布. 推导使用相应整列分布，并要求参数为正；digamma 渐近近似在小伪计数时须谨慎，不把近似当精确恒等式.

代回得到

$$\ln \widetilde{P}(\theta \mid y) = \ln P(\theta \mid y) + \ln \widetilde{P}(\theta) - \ln P(\theta) - \ln \mathbb{E}_{P(\theta|y)}\left[\frac{\widetilde{P}(\theta)}{P(\theta)}\right]. \tag{B.38}$$

由完整模型反演结果，就能计算若使用约简先验本会得到的证据与后验. 用变分量写为

$$F[P(\theta)] - F[\widetilde{P}(\theta)] = \ln \mathbb{E}_{Q(\theta)}\left[\frac{\widetilde{P}(\theta)}{P(\theta)}\right],$$

$$\ln \widetilde{Q}(\theta) = \ln Q(\theta) + \ln \widetilde{P}(\theta) - \ln P(\theta) - \ln \mathbb{E}_{Q(\theta)}\left[\frac{\widetilde{P}(\theta)}{P(\theta)}\right]. \tag{B.39}$$

译注：从精确后验替换为变分近似后，作为证据差的准确性仍受近似误差限制；源用等号，按源保留. 比值要求约简先验对完整先验具有适当绝对连续性及有限、非零期望；不能任意把完整先验外的支撑补入.

供参考，两类先验有明确形式，先是正态分布[3]：

$$\begin{aligned}
P(\theta) &= \mathcal{N}(\eta, \Sigma), & \widetilde{P}(\theta) &= \mathcal{N}(\tilde{\eta}, \tilde{\Sigma}),\\
Q(\theta) &= \mathcal{N}(\mu, C), & \widetilde{Q}(\theta) &= \mathcal{N}(\tilde{\mu}, \tilde{C}),\\
\tilde{C}^{-1} &= \widetilde{P} = P + \tilde{\Pi} - \Pi,\\
\tilde{\mu} &= \tilde{C}(P\mu + \tilde{\Pi}\tilde{\eta} - \Pi\eta),\\
\Delta F &= -\frac{1}{2}\ln|\tilde{\Pi}P\tilde{C}\Sigma|\\
&\quad + \frac{1}{2}(\mu \cdot P\mu + \tilde{\eta} \cdot \tilde{\Pi}\tilde{\eta} - \eta \cdot \Pi\eta - \tilde{\mu} \cdot \widetilde{P}\tilde{\mu}).
\end{aligned} \tag{B.40}$$

译注：本组第二高斯参数按源及章注是协方差，与本书多数前文以精确度为第二参数的记法不同；相应 $P = C^{-1}$、$\Pi = \Sigma^{-1}$、$\tilde{\Pi} = \tilde{\Sigma}^{-1}$ 为式中精确度矩阵，此处以译注明示这种读法，$\widetilde{P}$ 同时被用作矩阵名与约简分布记号，须按自变量区分. 约简后的精确度需正定.

实践中用于混合连续与范畴模型：每个范畴结果若关联一个连续先验，可不逐一反演，就高效评估各先验及相应范畴结果证据，例见第 8 章. 纯 POMDP 中更常比较 Dirichlet 先验假设，用于模拟概率矩阵元素剪除，作为睡眠中突触修剪的比喻（Friston, Lin et al. 2017），

$$\begin{aligned}
P(\theta) &= \mathrm{Dir}(a), & \widetilde{P}(\theta) &= \mathrm{Dir}(\tilde{a}),\\
Q(\theta) &= \mathrm{Dir}(\mathbf{a}), & \widetilde{Q}(\theta) &= \mathrm{Dir}(\tilde{\mathbf{a}}),\\
\tilde{\mathbf{a}} &= \mathbf{a} + \tilde{a} - a,\\
\Delta F &= \ln \mathrm{B}(\mathbf{a}) - \ln \mathrm{B}(\tilde{\mathbf{a}}) + \ln \mathrm{B}(\tilde{a}) - \ln \mathrm{B}(a).
\end{aligned} \tag{B.41}$$

B 为 Beta 函数. 多种其他分布也有类似结果（Friston, Parr, and Zeidman 2018），但正态与 Dirichlet 先验在主动推断中最常见.[42]

[42]译注：原式的先验/后验粗体与约简波浪号逐一保留；这里所有 Dirichlet 参数，包括更新后的 $\tilde{\mathbf{a}}$，均须在合法正参数域内，不能对非正参数直接套用 Beta 函数式.

B.3 （主动）广义滤波

从 POMDP 的范畴推断转到连续领域，便用到附录 A 的 Laplace 近似和运动广义坐标，还要构建含不同阶运动的精确度矩阵. 源此处指 A.5.2，实际矩阵位于第 A.5.3 节，即 A.5.3. 根据式 (A.33)、(A.34)，

$$
\begin{aligned}
F[q,\tilde{y}] &\approx -\frac{1}{2}\ln\left[(2\pi)^k|\tilde{\Sigma}|\right] - \ln p(\tilde{y},\tilde{\mu}),\\
q(\tilde{x}) &= \mathcal{N}(\tilde{\mu},\tilde{\Sigma}^{-1}),\\
\tilde{\Sigma}^{-1} &= -\nabla_{\tilde{x}}(\nabla_{\tilde{x}}\ln p(\tilde{y},\tilde{x}))^T\big|_{\tilde{x}=\tilde{\mu}}.
\end{aligned}
\tag{B.42}
$$

这是广义坐标下的 Laplace 自由能，作者称首行只有最后的生成模型项随 μ 变化.[43] 指定生成模型为

$$
\begin{aligned}
p(\tilde{y},\tilde{x},\tilde{v}) &= p(\tilde{y}\mid\tilde{x},\tilde{v})p(\tilde{x}\mid\tilde{v})p(\tilde{v}),\\
p(\tilde{y}\mid\tilde{x},\tilde{v}) &= \mathcal{N}(\tilde{g}(\tilde{x},\tilde{v}),\tilde{\Pi}_y),\\
p(\tilde{x}\mid\tilde{v}) &= \mathcal{N}(D\cdot\tilde{f}(\tilde{x},\tilde{v}),\tilde{\Pi}_x),\\
p(\tilde{v}) &= \mathcal{N}(\tilde{\eta},\tilde{\Pi}_x),\\
D\tilde{x} &= \tilde{f}(\tilde{x},\tilde{v})+\tilde{\omega}_x, \qquad \tilde{y} = \tilde{g}(\tilde{x},\tilde{v})+\tilde{\omega}_y.
\end{aligned}
\tag{B.43}
$$

现在有两个隐变量：x 依赖运动方程 f，v 依赖静态先验. D 在主对角线上方为 1，在广义坐标中，相当于将时间导数向量各项上移一位，即时间求导. 广义精确度按第 A.5.3 节构建.[44]

代入得到

$$
\begin{aligned}
F[q,\tilde{y}] &= \underbrace{\frac{1}{2}\tilde{\varepsilon}_y\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y}_{-\ln p(\tilde{y}|\tilde{\mu}_x,\tilde{\mu}_v)} + \underbrace{\frac{1}{2}\tilde{\varepsilon}_x\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x}_{-\ln p(\tilde{\mu}_x|\tilde{\mu}_v)} + \underbrace{\frac{1}{2}\tilde{\varepsilon}_v\cdot\tilde{\Pi}_v\tilde{\varepsilon}_v}_{-\ln p(\tilde{\mu}_v)},\\
\tilde{\varepsilon}_y &\triangleq \tilde{y}-\tilde{g}(\tilde{\mu}_x,\tilde{\mu}_v),\\
\tilde{\varepsilon}_x &\triangleq D\tilde{\mu}_x-\tilde{f}(\tilde{\mu}_x,\tilde{\mu}_v), \qquad \tilde{\varepsilon}_v \triangleq \tilde{\mu}_v-\tilde{\eta}.
\end{aligned}
\tag{B.44}
$$

这里略去对 μ 为常数的项. 用第 A.2.2 节恒等式求梯度，

$$
\begin{aligned}
\nabla_{\tilde{\mu}_x}F[q,\tilde{y}] &= -\nabla_{\tilde{\mu}_x}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y + D\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x - \nabla_{\tilde{\mu}_x}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x,\\
\nabla_{\tilde{\mu}_v}F[q,\tilde{y}] &= -\nabla_{\tilde{\mu}_v}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y - \nabla_{\tilde{\mu}_v}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x + \tilde{\Pi}_v\tilde{\varepsilon}_v.
\end{aligned}
\tag{B.45}
$$

普通梯度下降在最小自由能处使 μ 静止，若高阶运动非零，显然不理想. 可改在移动参考系中下降，使最小处仍以 μ' 速度运动，

$$
\begin{aligned}
\dot{\tilde{\mu}}_x - D\tilde{\mu}_x &= \nabla_{\tilde{\mu}_x}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y - D\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x + \nabla_{\tilde{\mu}_x}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x,\\
\dot{\tilde{\mu}}_v - D\tilde{\mu}_v &= \nabla_{\tilde{\mu}_v}\tilde{g}\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y + \nabla_{\tilde{\mu}_v}\tilde{f}\cdot\tilde{\Pi}_x\tilde{\varepsilon}_x - \tilde{\Pi}_v\tilde{\varepsilon}_v.
\end{aligned}
\tag{B.46}
$$

[43]译注：如附录 A 所注，精确度 Hessian 一般随众数变化，故对数行列式也可变化；仅保留末项梯度须相应固定曲率或忽略更高导数近似，不由 Laplace 假设本身普遍推出.

[44]译注：源 $p(\tilde{x}\mid\tilde{v})$ 的均值用 $D\cdot\tilde{f}$，与后面的 $D\tilde{x}=\tilde{f}+\tilde{\omega}_x$ 之间有转置/密度对象疑点；源 $p(\tilde{v})$ 精确度下标写 x，而后续用 v，照源保留并指出.

这指定预测编码方案：预测误差驱动期望更新，消除误差. 复制到额外层级，并把 y 换为低层 v，即可扩展，

$$\begin{aligned}
\dot{\tilde{\mu}}_x^{(i)} - D\tilde{\mu}_x^{(i)} &= \nabla_{\tilde{\mu}_x^{(i)}}\tilde{g}\cdot\tilde{\Pi}_v^{(i-1)}\tilde{\varepsilon}_v^{(i-1)} - D\cdot\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)} \\
&\quad + \nabla_{\tilde{\mu}_x^{(i)}}\tilde{f}^{(i)}\cdot\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)}, \\
\dot{\tilde{\mu}}_v^{(i)} - D\tilde{\mu}_v^{(i)} &= \nabla_{\tilde{\mu}_v^{(i)}}\tilde{g}^{(i)}\cdot\tilde{\Pi}_v^{(i-1)}\tilde{\varepsilon}_v^{(i-1)} + \nabla_{\tilde{\mu}_v^{(i)}}\tilde{f}^{(i)}\cdot\tilde{\Pi}_x^{(i)}\tilde{\varepsilon}_x^{(i)} \\
&\quad + \tilde{\Pi}_v^{(i)}\tilde{\varepsilon}_v^{(i)}, \\
\tilde{\varepsilon}_v^{(i)} &\triangleq \tilde{\mu}_v^{(i)} - \tilde{g}^{(i+1)}(\tilde{\mu}_x^{(i+1)}, \tilde{\mu}_v^{(i+1)}), \\
\tilde{\varepsilon}_x^{(i)} &\triangleq D\tilde{\mu}_x^{(i)} - \tilde{f}^{(i)}(\tilde{\mu}_x^{(i)}, \tilde{\mu}_v^{(i)}).
\end{aligned} \tag{B.47}$$

译注：源本式第二行最后是正的 $\tilde{\Pi}_v^{(i)}\tilde{\varepsilon}_v^{(i)}$，与式 (B.46) 中负号不一致，按源保留. 第一行 $\tilde{g}$ 亦按原式未加层号；不能把照录的这两处差异误判成已经验证的下降动力学.

主动推断不只通过知觉，也通过行动最小化自由能. 行动只改变感觉输入 y，所以大多数自由能项与它无关；对行动下降得到

$$\dot{u} = -\nabla_u\tilde{y}(u)\cdot\tilde{\Pi}_y\tilde{\varepsilon}_y. \tag{B.48}$$

式 (B.47)、(B.48) 共同给出连续状态空间主动推断的广泛描述. 这里不展开学习或混合模型，分别已在框 8.2、8.3 概括.

Appendix C

Matlab 代码的带注释示例

C.1 引言

这里给出指定、求解生成模型所需 Matlab 代码的带注释示例，使用 SPM12 的标准反演与绘图例程，重现第 7 章 T 形迷宫觅食. 单独阅读略显枯燥，最适合读者尝试在 Matlab 实现、观察运作. 建议尝试不同参数、改变生成模型，设法把演示 “弄坏”；只有如此才能逐渐形成主动推断机制的直觉.

C.2 准备

假定读者熟悉 Matlab，并已从以下地址下载 SPM12：

https://www.fil.ion.ucl.ac.uk/spm/

先把 SPM12 函数所在文件夹加入 Matlab 路径，再打开脚本，定义并命名函数，这里为 `demo_AI_book`：图 C.1 第二行把随机数生成器设为默认初始种子，使每次函数产生

```
function demo_AI_book
rng default
```

图 C.1: 函数定义与随机数设置.

相同随机数. 演示通常这样保证可重复性；若多次运行以计算行为的跨试验汇总统计，可略去. 最好附说明脚本的注释；但本附录本就专门注释，故原示例略去该文档.

再把后续常数集中定义，便于日后查找和扰动. 定义两个概率参数，作用见第 C.3 节，保证 $a + b = 1$. 接下来设置定义生成模型的 A、B、C、D 数组. 简单模拟假定生成模

```
a = .98;
b = 1 - a;
```

图 C.2: 两个互补概率.

型与生成过程参数相同.

C.3 似然

这里着重如何用 Matlab 形式化似然矩阵，不详述生成模型或范式. 源文指向原 7.2，实际迷宫说明见第 7 章相应部分. 要把图 7.4、7.5 的似然矩阵转成反演例程可理解的语

言. A^1 写作 `A{1}`，花括号内数对应上标，即结果模态. 矩阵，更严格说张量，由三个下标定位：结果、第一个位置隐状态、第二个情境隐状态；这些放在圆括号内. 第二隐状态因子的第一水平，即吸引刺激在右侧的情境，以第三下标 1 指定；左侧则用 2，行是结果，列是第一隐状态因子的备选水平. 与图 7.4、7.5 比较可帮助理解. A^2 也按情境定义，使用前述 a、b，至此完整指定 A：两种模态、即上标或花括号下，对每个双隐状态因子取值组合，即第二、三下标，定义了各结果行的概率.[45]

C.4 转移概率

指定 B 时，上标或花括号表示隐状态因子，而非 A 的结果模态. 因子 1 是位置，2 是情境. 每个矩阵从上一时间状态列映射至当前状态行；若因子可控，转移还可随行动改变，须额外下标指定行动，这里为可控位置定义四种行动，各指向四位置之一. 左右臂是吸收状态，进入后必须留在那里. 分号表示矩阵行末. 情境不受生物控制，无须为各行动指定不同转移，只定义 Matlab 中称为 `eye` 的单位矩阵. 这实现图 7.6 与式 (7.5) 的指定.

C.5 先验偏好与初始状态

接着是 C，其上标和花括号与 A 一样表示结果模态；D 则与 B 一样对应隐状态因子. C、D 行数分别须与相关 A、B 的行数相符，C 以不必归一化的对数概率指定偏好；两结果相差 6，更可能者的概率是另一者的 $\exp(6)$ 倍. 行为不同结果，列为时间步，因此可以随时间改变；若只一列，默认各时刻相同. D 为各试验初始状态赋概率，可与式 (7.6)、(7.7) 比较. Matlab 转置用 ASCII 单引号`'` 表示.

C.6 策略空间

B 已隐式指定允许行动. 可令策略与行动相同，每步选新策略；也可把策略指定为行动序列，各策略说明各步使用第三下标指定的哪个 B 矩阵. 通过数组 V 实现，V 第一维，即行，是序列位置，第一行为第一行动，第二行为第二行动；行动产生转移，所以三步模型只需两行动. 第二维列是备选策略；第三维是隐状态因子. 例如 `V(2,5,1)=3`，表示第五策略选择第三行动对应的位置 B^1，完成从第二到第三步的转移. 简单模拟可包括所有可能策略，其他情况下也可只选子集. 但可用策略的选择本身是一项设计选择，会影响行为.

C.7 整合

指定 POMDP 后，整合至单个 `mdp` 变量，末行指定希望起始的真实隐状态；模拟

[45]译注：原图 C.4 中情境 1 的正奖赏行在位置第三列，即左臂，取 $a = .98$，第四列右臂为 $b = .02$，与上段及 C.3 右线索对情境 1 的文字命名相反. 源代码与注释均保留，不以改矩阵来暗中消除情境语义冲突.

```
A{1}(:, :, 1) = [...
    1 0 0 0;  % start
    0 0 0 0;  % left cue
    0 1 0 0;  % right cue
    0 0 1 0   % left
    0 0 0 1]; % right
A{1}(:, :, 2) = [...
    1 0 0 0;  % start
    0 1 0 0;  % left cue
    0 0 0 0;  % right cue
    0 0 1 0   % left
    0 0 0 1]; % right
```

图 C.3: 第一结果模态的似然，保留原代码注释；start、left/right cue、left/right 分别为起点、左/右线索、左/右位置.

```
A{2}(:, :, 1) = [...
    1 1 0 0;  % reward neutral
    0 0 a b;  % reward positive
    0 0 b a]; % reward negative
A{2}(:, :, 2) = [...
    1 1 0 0;  % reward neutral
    0 0 b a;  % reward positive
    0 0 a b]; % reward negative
```

图 C.4: 第二结果模态的似然；reward neutral/positive/negative 为中性/正/负奖赏.

```
B{1}(:, :, 1) = [1 1 0 0; 0 0 0 0; 0 0 1 0; 0 0 0 1];
B{1}(:, :, 2) = [0 0 0 0; 1 1 0 0; 0 0 1 0; 0 0 0 1];
B{1}(:, :, 3) = [0 0 0 0; 0 0 0 0; 1 1 1 0; 0 0 0 1];
B{1}(:, :, 4) = [0 0 0 0; 0 0 0 0; 0 0 1 0; 1 1 0 1];
B{2} = eye(2);
```

图 C.5: 位置与情境转移概率.

```
C{1} = [-1 -1 -1;
         0  0  0;
         0  0  0;
         0  0  0;
         0  0  0];
c = 6;
C{2} = [ 0  0  0;
         c  c  c;
        -c -c -c];
D{1} = [1 0 0 0]';
D{2} = [1 1]'/2;
```

图 C.6: 对数偏好及初始状态先验.

```
V(:, :, 1) = [1 1 1 1 3 4 2 2 2 2
              1 2 3 4 3 4 1 2 3 4];
V(:, :, 2) = 1;
```

图 C.7: 允许的行动序列.

```
mdp.V = V;       % allowable policies
mdp.A = A;       % observation model
mdp.B = B;       % transition probabilities
mdp.C = C;       % preferred outcomes
mdp.D = D;       % prior over initial states
mdp.S = [1 1]';  % true initial state
```

图 C.8: 整合模型；注释依次为允许策略、观测模型、转移概率、偏好结果、初始状态先验、真实初态.

生物不知道它，只能依据生成的结果及前五行模型推断状态.[46]

C.8 模拟与绘图

主要工作由 `spm_MDP_VB_X` 在后台完成，实现第 4、7 章的消息传递和策略选择，还模拟状态转移与结果生成等外部世界过程. 还有许多选项，详见 Matlab 脚本中的函数文档.

模拟一次试验后，常需图形表示结果；标准例程可自动产生图 7.2、7.7 那类图，这

```
MDP = spm_MDP_VB_X(mdp);
spm_figure('GetWin', 'Figure 1'); clf
spm_MDP_VB_trial(MDP);
spm_figure('GetWin', 'Figure 2'); clf
spm_MDP_VB_LFP(MDP, [], 1);
spm_figure('GetWin', 'Figure 3'); clf
spm_MDP_VB_LFP(MDP, [], 2);
```

图 C.9: 调用标准反演与绘图例程.

些行模拟并绘制三幅图：第一幅总结状态、结果、所选策略和回顾推断；第二幅显示第一隐状态因子信念更新的电生理对应量，第三幅显示第二因子. 图 C.10 重现原书首组代码输出，以便读者确认运作. 原作者也可展示其余两图，但选择让读者自行运行，进行主动推断，降低对图形内容的不确定性.

本简单注释示例到此结束，希望引导读者探索依同一原理和语法构建的丰富模型. 在 Matlab 命令行键入 `DEM`，可从图形界面选择其他演示. 这里是 Friston, FitzGerald et al.（2017）例程的简化版；关于多次试验的模型学习等更多细节，见该论文与 SPM12 中的 `DEM_demo_MDP_X.m`.

完整可编辑脚本保存为 `code/demo_AI_book.m`. 只将排版用弯引号、负号恢复为可执行 ASCII 字符，调整无语义空白；保留源矩阵、常数、语句、字段大小写及原英文注释，末行大写 S 的疑点不修造. 本阶段做源代码 token 和矩阵结构核对，未下载 SPM、训练或运行模拟.

[46]译注：源图 C.8 字段明确印为大写 `mdp.S`，本稿原样保留，不未经所用 SPM12 版本核实就改成其他大小写字段. 本地未安装或执行此依赖，代码照录与数值模拟成功是不同状态.

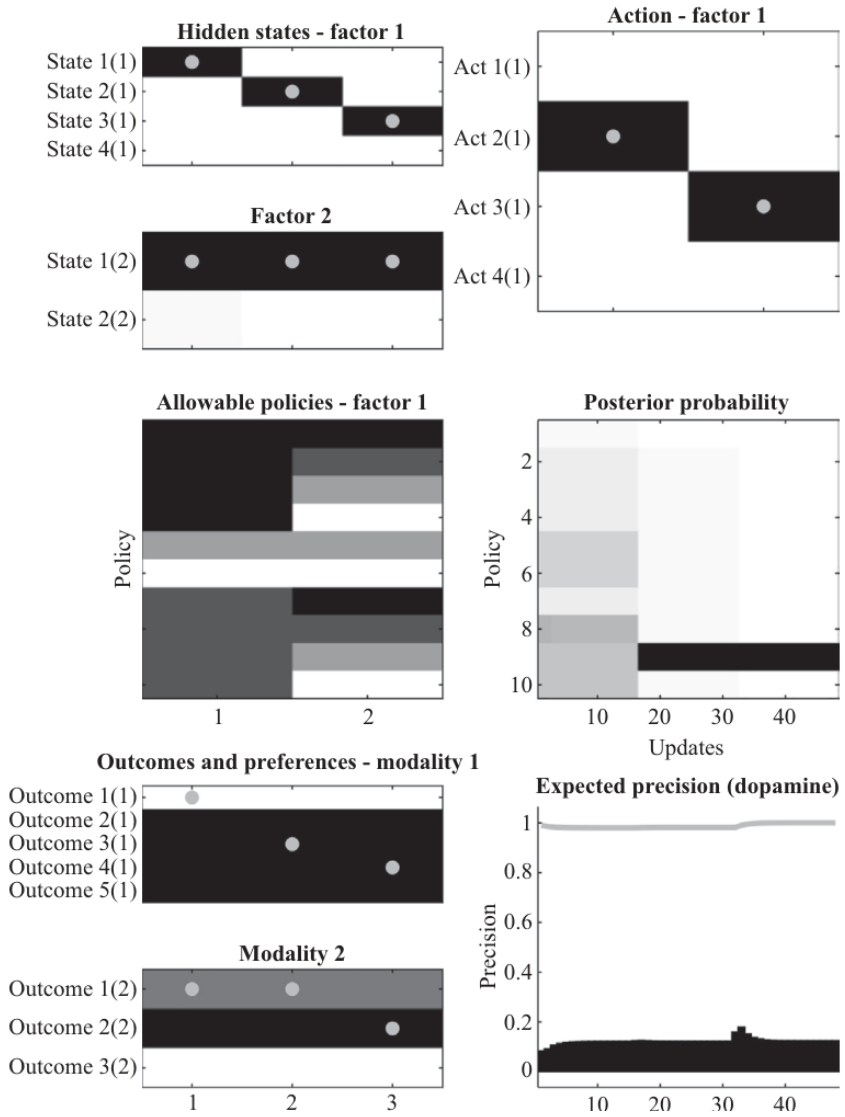


图 C.10: 原书 `spm_MDP_VB_trial` 的输出，忠实源裁图，未冒称本次重新模拟所得. 左上: 全部观测后、回顾性隐状态因子信念, 黑为概率 1、白为 0; 灰点在彩色图为青色, 是模拟环境真实状态，大鼠准确确信地推断位置因子 1 和情境因子 2. 左中: 第 C.6 节 V 的允许策略, 各行一策略, 两列为两行动, 灰度表示行动. 左下: 各模态真实结果灰点; 背景为 C, 越暗越偏好. 右上: 推断与选择的行动. 右中: 各时间步的策略信念. 右下: 策略信念推断精确度灰线及其变化率条形图，类似电生理多巴胺放电栅格图. 时间按自由能梯度下降的更新次数表示，默认每步 16 次. 图内 Hidden states/Action/Allowable policies/Posterior probability/Outcomes and preferences/Expected precision 为隐状态/行动/允许策略/后验概率/结果与偏好/期望精确度; factor、modality、State、Act、Outcome、Policy、Time、Updates 分别为因子、模态、状态、行动、结果、策略、时间、更新次数; dopamine 为多巴胺.

注释

第 1 章

1. “规范性” 一词意味着存在某种可供评估行为的标准. 主动推断是规范性的，因为它以自由能这一量来评估知觉和行动；我们将在本章和后续章节中阐明这一量.

2. 贝叶斯最优性指一组相互关联的概念，它们涉及贝叶斯定理的不同方面；我们将在第 2 章阐明贝叶斯定理. 大体而言，它指在给定某个观测的条件下，使某种代价（或效用）函数的期望值最小化（或最大化）的任何行动. 这包括贝叶斯最优实验设计：选择实验（行动）以最大化期望信息增益.

第 2 章

1. 与比特一样，奈特也是信息单位. 选择哪种单位取决于我们使用以 2 为底的对数（比特），还是自然对数（奈特）.

2. 支撑集是一个技术术语，指分布可能接受的自变量取值. 例如，范畴概率分布的支撑集是一组备选状态，即其概率可以被量化的事件空间. 单变量正态分布的支撑集是整条实数轴.

3. 理解主动推断的概念并不需要掌握这个表的细节；不过，对于感兴趣的读者，我们简要阐明其要点. 支撑集一列告诉我们每个分布可用于量化哪些变量的惊异. 对高斯分布而言，这是实数集. 对多项分布而言，支撑集由一组 K 个变量构成，每个变量取最大为 N 的整数值，并受限于这一组中所有元素之和为 N. 对狄利克雷分布而言，支撑集包括 0 和 1 之间的任意一组 K 个实数，其所有元素之和为 1. 伽马分布量化非负实数的惊异. 惊异一列展示了惊异的计算方法；除了随机变量 x 外，它还取决于控制底层分布形状的常数.

4. 值得注意的是，资源限制并非精确贝叶斯推断的唯一障碍. 对复杂模型而言，精确推断在解析上可能难以求解，以至于增加再多资源也无法解决这一精确问题.

5. 与 KL 散度一样，熵是信息论中的一个量，度量概率分布的分散程度或不确定性. 从技术上说，它是负对数概率的平均值，即平均惊异.

6. 这里的复杂度衡量的是，为解释数据，我们必须在多大程度上偏离关于世界的先验信念.

7. 之所以称为准确度，是因为当在所推断的隐状态下预期的结果对观测数据赋予较高的对数概率时，解释的准确度就会提高；即预测的结果分布准确地捕捉到测量所得的分布.

第 3 章

1. 这里的非平衡指不存在细致平衡. 细致平衡是系统达到稳态后在时间反演下的不变性. 图 3.3 左侧的系统不具有细致平衡，因为轨迹倾向于绕惊异的等高线逆时针弯曲. 若将其倒放，系统看起来会顺时针旋转.

2. 这并不等同于说最小化惊异的系统必须最小化其熵. 如图 3.3 所示，系统并不趋向能够使熵最小化的无限精确的点分布，而是随时间维持一致的分散程度，即对熵同时施加上界和下界.

3. 原文使用大写的 Action，以区分作为拉格朗日量路径积分的作用量与作为马尔可夫毯主动状态动力学的行动.

4. 拉格朗日量是位置和速度的函数，给出动能与势能之差. 哈密顿量与之通过勒让德变换相关联，并用位置与动量表达系统的总能量.

第 4 章

1. 此处及全章对模型的条件依赖均隐去，因此模型证据写作 $P(y)$ 而不是 $P(y \mid m)$.

2. 严格来说，这对任何凹函数都成立，但这里我们只关心对数.

3. 期望是方括号中各项的加权和或积分，每项的权重由下标所示概率给出，见框 2.2.

4. 本书遵循物理学家的约定，把自由能视为负对数证据的上界. 其他学科，包括统计学和机器学习，使用负自由能作为证据下界（ELBO）. 这两者完全等价，但可能在跨学科研究中造成混淆.

5. MAP 估计是考虑先验信念与现有数据后的最可能状态；相比之下，最大似然方法不考虑先验信念.

第 5 章

1. 这一命名来自强化学习理论（Daw et al. 2005），但略有误导，因为两个系统都依赖模型. “无模型” 系统只是使用一种更简单的模型，预测某类环境中的某种行为.

第 6 章

1. 从神经角度看，这并不意味着离散的时间动力学. 相反，连续的神经动力学被视为表示关于离散事件序列的信念的连续变化.

2. 话虽如此，在连续时间模型中使用运动的广义坐标，见框 4.2，意味着这些模型通过隐式表示一小段轨迹而具有时间深度. 不过，这些模型不一定包含表示可采取的备选轨迹，即行动序列后果，的变量.

3. 不要把具有时间深度的模型与层级模型混淆. 与具有时间深度的模型不同，一些层级模型，例如预测编码模型，见第 4.5.1 节，只考虑当前观测. 不过，生成模型可以既具有层级结构，又具有时间深度，从而实现多尺度规划.

第 8 章

1. 往往必须加入阻尼项，计入摩擦和/或黏性，以排除振荡解.

第 9 章

1. 实践中，常把参数定义为对数尺度参数：尺度因子非负，不能由会给负数分配有限概率密度的正态分布刻画. 改为假定尺度参数的对数服从正态分布，指数变换后就保证参数为正. 将参数的平方根建模为正态分布，也能达到同一目标.[47]

2. 例如，$\partial_x f(x) \approx \frac{1}{2\Delta x}[f(x+\Delta x) - f(x-\Delta x)]$.

第 10 章

1. 更实用地看，主动推断只须习得前向模型；由于它通常只是行动与后果的直接、可观测映射，相比逆模型更容易学习. 前向模型还可通过模仿或外部监督获得，后者是与主动推断大体类似、广泛用于训练机器人模型的技术（Nishimoto and Tani 2009）.

2. 机器学习中，优化行动序列有时称为序列策略优化，区别于更常见的状态—行动策略优化，即 “若我在此状态，应做什么？”.

3. 有效部署认知资源的概念内在于自由能最小化，因为最小复杂度会在信息论与热力学意义上自动最大化效率. 简言之，最小阻力路径就是最小自由能路径.[48]

附录 A

1. 张量推广标量、向量和矩阵，可直观视为需一定数目下标定位元素的数组. 向量只需一个行下标，故 1 阶；矩阵需行列两个下标，故 2 阶；标量不需下标，故 0 阶.

2. 使用恒等式 $\partial_A \ln|A| = A^{-1}$.[49]

3. 变分推断中，该积分通常是期望.

4. 有时称为变分法基本引理.

[47]译注：平方正态变量可为非负，但一般不同于对数正态分布；源句所称同一目标是非负性，并非两种参数先验完全等价.

[48]译注：本注保留作者的物理类比和概括力度；信息论复杂度与具体生物计算的热力学耗散、时间和资源代价之间的对应，须有另行模型与条件，不能把一句类比当作普遍效率证明.

[49]译注：按通常逐元素矩阵梯度，结果一般为 A^{-T}；对称矩阵约定下可与源式一致，需结合本书导数约定，不能不加条件推广到任意矩阵.

5. 使用对数导数的链式法则：$\partial_x \ln f(x) = f(x)^{-1}\partial_x f(x)$.

附录 B

1. 归一化指数函数.

2. 为简洁，省略了对数配分函数导数中的某些项；所选变分分布允许这样做，因为任何更高阶多项式项都会违背其形式.[50]

3. 这里的 C 是协方差，虽与前几节先验偏好同记号，但不要混淆.

[50]译注：这是源对近似/截断的说明，保留其适用语境，并不意味着任意被省略项都严格为 0；实际学习方程仍需依具体变分族和参数化核实.

参考文献

原书完整参考文献按原顺序保留作者、题名与刊名，便于检索；未补造新文献、DOI 或版本. 此处仅复现冻结 2022 版书目，不代表对每条书目另作外部真实性核验. 原始条目、页码和文本规范化记录随源码保存.

Ackley, D. H., G. E. Hinton, and T. J. Sejnowski (1985). “A learning algorithm for Boltzmann machines.” Cognitive Science 9(1): 147–169.

Adams, R. A., E. Aponte, L. Marshall, and K. J. Friston (2015). “Active inference and oculomotor pursuit: the dynamic causal modelling of eye movements.” Journal of Neuroscience Methods 242: 1–14.

Adams, R. A., M. Bauer, D. Pinotsis, and K. J. Friston (2016). “Dynamic causal modelling of eye movements during pursuit: confirming precision-encoding in V1 using MEG.” NeuroImage 132: 175–189.

Adams, R. A., L. U. Perrinet, and K. Friston (2012). “Smooth pursuit and visual occlusion: Active Inference and oculomotor control in schizophrenia.” PLOS ONE 7(10): e47502.

Adams, R. A., S. Shipp, and K. J. Friston (2013). “Predictions not commands: Active Inference in the motor system.” Brain Structure and Function 218(3): 611–643.

Adams, R. A., K. E. Stephan, H. R. Brown, C. D. Frith, and K. J. Friston (2013). “The computational anatomy of psychosis.” Frontiers in Psychiatry 4: 47.

Aghajanian, G. K., and G. J. Marek (1999). “Serotonin, via 5-HT2A receptors, increases EPSCs in layer V pyramidal cells of prefrontal cortex by an asynchronous mode of glutamate release.” Brain Research 825(1): 161–171.

Ahmadi, A., and J. Tani (2019). “A novel predictive-coding-inspired variational RNN model for online prediction and recognition.” Neural Computation 31(11): 2025–2074.

Aitchison, L., and M. Lengyel (2017). “With or without you: predictive coding and Bayesian inference in the brain.” Current Opinion in Neurobiology 46: 219–227.

Allen, M., A. Levy, T. Parr, and K. J. Friston (2019). “In the body’s eye: the computational anatomy of interoceptive inference.” bioRxiv 603928.

Anderson, B. A., P. A. Laurent, and S. Yantis (2011). “Value-driven attentional capture.” Proceedings of the National Academy of Sciences 108(25): 10367.

Arnal, L. H., and A.-L. Giraud (2012). “Cortical oscillations and sensory predictions.” Trends in Cognitive Sciences 16(7): 390–398.

Arnsten, A. F. T., and B.-M. Li (2005). “Neurobiology of executive functions: catecholamine influences on prefrontal cortical functions.” Biological Psychiatry 57(11): 1377–1384.

Ashby, W. R. (1952). Design for a Brain. Oxford: Wiley.

Attias, H. (2003). "Planning by probabilistic inference." Proceedings of the 9th International Workshop on Artificial Intelligence and Statistics, Key West, Florida, USA.

Baldassarre, G., and M. Mirolli (2013). Intrinsically Motivated Learning in Natural and Artificial Systems. New York: Springer.

Barca, L., and G. Pezzulo (2020). "Keep your interoceptive streams under control: an Active Inference perspective on anorexia nervosa." Cognitive, Affective and Behavioral Neuroscience 20(2): 427–440.

Barrett, L. F. (2017). How Emotions Are Made: The Secret Life of the Brain. Boston, MA: Houghton Mifflin Harcourt.

Barrett, L. F., K. S. Quigley, and P. Hamilton (2016). "An Active Inference theory of allostasis and interoception in depression." Philosophical Transactions of the Royal Society B 371(1708): 20160011.

Barrett, L. F., and W. K. Simmons (2015). "Interoceptive predictions in the brain." Nature Reviews Neuroscience 16(7): 419–429.

Barsalou, L. W. (2008). "Grounded cognition." Annual Review of Psychology 59: 617–645.

Bastos, A. M., V. Litvak, R. Moran, C. A. Bosman, P. Fries, and K. J. Friston (2015). "A DCM study of spectral asymmetries in feedforward and feedback connections between visual areas V1 and V4 in the monkey." Neuroimage 108: 460–475.

Bastos, A. M., W. M. Usrey, R. A. Adams, G. R. Mangun, P. Fries, and K. J. Friston (2012). "Canonical microcircuits for predictive coding." Neuron 76(4): 695–711.

Beal, M. J. (2003). "Variational algorithms for approximate Bayesian inference." PhD diss., University of London.

Bellman, R. (1954). "The theory of dynamic programming." Bulletin of the American Mathematical Society 60(6): 503–515.

Benrimoh, D., T. Parr, P. Vincent, R. A. Adams, and K. Friston (2018). "Active Inference and auditory hallucinations." Computational Psychiatry 2: 183–204.

Berridge, K. C. (2007). "The debate over dopamine's role in reward: the case for incentive salience." Psychopharmacology 191(3): 391–431.

Berridge, K. C., and M. L. Kringelbach (2011). "Building a neuroscience of pleasure and well-being." Psychology of Well-Being 1(1): 1–3.

Botvinick, M., and M. Toussaint (2012). "Planning as inference." Trends in Cognitive Sciences 16(10): 485–488.

Botvinick, M. M. (2008). "Hierarchical models of behavior and prefrontal function." Trends in Cognitive Sciences 12(5): 201–208.

Brown, H., R. A. Adams, I. Parees, M. Edwards, and K. Friston (2013). "Active Inference, sensory attenuation and illusions." Cognitive Processing 14(4): 411–427.

Brown, H., and K. Friston (2012). "Free-energy and illusions: the cornsweet effect." Frontiers in Psychology 3(43).

Brown, L. D. (1981). "A complete class theorem for statistical problems with finite-sample spaces." Annals of Statistics 9(6): 1289–1300.

Bruineberg, J., J. Kiverstein, and E. Rietveld (2016). "The anticipating brain is not a scientist: the free-energy principle from an ecological-enactive perspective." Synthese 195: 2417–2444.

Bruineberg, J., E. Rietveld, T. Parr, L. van Maanen, and K. J. Friston (2018). "Free-energy minimization in joint agent-environment systems: a niche construction perspective." Journal of Theoretical Biology 455: 161–178.

Buzsaki, G. (2019). The Brain from Inside Out. New York: Oxford University Press.

Callaway, E. M., and A. K. Wiser (2009). "Contributions of individual layer 2–5 spiny neurons to local circuits in macaque primary visual cortex." Visual Neuroscience 13(5): 907–922.

Cannon, W. B. (1929). "Organization for physiological homeostasis." Physiological Reviews 9(3): 399–431.

Ciria, A., G. Schillaci, G. Pezzulo, V. V. Hafner, and B. Lara (2021). "Predictive processing in cognitive robotics: a review." arXiv preprint arXiv:2101.06611.

Cisek, P. (2019). "Resynthesizing behavior through phylogenetic refinement." Attention, Perception, and Psychophysics 81(7): 2265–2287.

Clark, A. (2013). "Whatever next? Predictive brains, situated agents, and the future of cognitive science." Behavioral and Brain Sciences 36(03): 181–204.

Clark, A. (2015). Surfing Uncertainty: Prediction, Action, and the Embodied Mind. New York: Oxford University Press.

Clark, A., and D. J. Chalmers (1998). "The extended mind." Analysis 58: 10–23.

Clark, J. E., S. Watson, and K. J. Friston (2018). "What is mood? A computational perspective." Psychological Medicine 48(14): 2277–2284.

Collins, S. H., M. Wisse, and A. Ruina (2016). "A three-dimensional passive-dynamic walking robot with two legs and knees." International Journal of Robotics Research 20(7): 607–615.

Conant, R. C., and W. R. Ashby (1970). "Every good regulator of a system must be a model of that system." International Journal of Systems Science 1(2): 89–97.

Corcoran, A. W., G. Pezzulo, and J. Hohwy (2020). "From allostatic agents to counterfactual cognisers: Active Inference, biological regulation, and the origins of cognition." Biology and Philosophy 35(3): 32.

Corlett, P. R., G. Horga, P. C. Fletcher, B. Alderson-Day, K. Schmack, and A. R. Powers III (2019). "Hallucinations and strong priors." Trends in Cognitive Sciences 23(2): 114–127.

Cox, D. R., and H. D. Miller (1965). "The theory of stochastic processes." London: Chapman and Hall/CRC.

Craik, K. (1943). The Nature of Explanation. Cambridge: Cambridge University Press.

Cullen, M., B. Davey, K. J. Friston, and R. J. Moran (2018). "Active inference in OpenAI gym: a paradigm for computational investigations into psychiatric illness." Biological Psychiatry: Cognitive Neuroscience and Neuroimaging 3(9): 809–818.

Da Costa, L., T. Parr, N. Sajid, S. Veselic, V. Neacsu, and K. Friston (2020). "Active Inference on discrete state-spaces: a synthesis." arXiv preprint arXiv:2001.07203.

Daunizeau, J., H. E. M. den Ouden, M. Pessiglione, S. J. Kiebel, K. E. Stephan, and K. J. Friston (2010). "Observing the observer (I): meta-Bayesian models of learning and decision-making." PLOS ONE 5(12): e15554.

Dauwels, J. (2007). "On variational message passing on factor graphs." 2007 IEEE International Symposium on Information Theory, 2546–2550.

Daw, N. D., Y. Niv, and P. Dayan (2005). "Uncertainty-based competition between prefrontal and dorsolateral striatal systems for behavioral control." Nature Neuroscience 8(12): 1704–1711.

Dayan, P., G. E. Hinton, R. M. Neal, and R. S. Zemel (1995). "The Helmholtz machine." Neural Computation 7: 889–904.

Demirdjian, D., L. Taycher, G. Shakhnarovich, K. Grauman, and T. Darrell (2005). "Avoiding the 'streetlight effect': tracking by exploring likelihood modes." In Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1, 357–364.

Dennett, D. C. (1978). "Why not the whole iguana?" Behavioral and Brian Sciences 1: 103–104.

Dickinson, A., and B. Balleine (1990). "Motivational control of instrumental performance following a shift from thirst to hunger." Quarterly Journal of Experimental Psychology 42(4): 413–431.

Disney, A. A., C. Aoki, and M. J. Hawken (2007). "Gain modulation by nicotine in Macaque V1." Neuron 56(4): 701–713.

Donnarumma, F., M. Costantini, E. Ambrosini, K. Friston, and G. Pezzulo (2017). "Action perception as hypothesis testing." Cortex: A Journal Devoted to the Study of the Nervous System and Behavior 89: 45–60.

Doya, K. (2007). Bayesian Brain: Probabilistic Approaches to Neural Coding. Cambridge, MA: MIT Press.

Elliott, M. C., P. M. Tanaka, R. W. Schwark, and R. Andrade (2018). "Serotonin differentially regulates L5 pyramidal cell classes of the medial prefrontal cortex in rats and mice." eNeuro 5(1): eneuro.0305–0317.2018.

Feldman, A. G. (2009). "New insights into action-perception coupling." Experimental Brain Research 194(1): 39–58.

Feldman, A. G., and M. F. Levin (2009). "The equilibrium-point hypothesis—past, present and future." In Progress in Motor Control: A Multidisciplinary Perspective, edited by D. Sternad, 699–726. Boston, MA: Springer US.

Feldman, H., and K. Friston (2010). "Attention, uncertainty, and free-energy." Frontiers in Human Neuroscience 4(215).

Felleman, D. J., and D. C. Van Essen (1991). "Distributed hierarchical processing in the primate cerebral cortex." Cerebral Cortex 1(1): 1–47.

Fiser, J., P. Berkes, G. Orbán, and M. Lengyel (2010). "Statistically optimal perception and learning: from behavior to neural representations." Trends in Cognitive Sciences 14(3): 119–130.

FitzGerald, T. H. B., R. J. Dolan, and K. Friston (2015). "Dopamine, reward learning, and active inference." Frontiers in Computational Neuroscience 9: 1–16.

FitzGerald, T. H. B., P. Schwartenbeck, M. Moutoussis, R. J. Dolan, and K. Friston (2015). "Active inference, evidence accumulation, and the urn task." Neural Computation 27(2): 306–328.

Foster, D. (2019). Generative Deep Learning: Teaching Machines to Paint, Write, Compose, and Play. Boston: O'Reilly Media.

Fountas, Z., N. Sajid, P. A. M. Mediano, and K. Friston (2020). "Deep active inference agents using Monte-Carlo methods." arXiv:2006.04176 [cs, q-bio, stat].

Fradkin, I., R. A. Adams, T. Parr, J. P. Roiser, and J. D. Huppert (2020). "Searching for an anchor in an unpredictable world: a computational model of obsessive compulsive disorder." Psychological Review 127(5): 672–699.

Frank, M. J. (2005). "Dynamic dopamine modulation in the basal ganglia: a neurocomputational account of cognitive deficits in medicated and nonmedicated Parkinsonism." Journal of Cognitive Neuroscience 17(1): 51–72.

Freeze, B. S., A. V. Kravitz, N. Hammack, J. D. Berke, and A. C. Kreitzer (2013). "Control of basal ganglia output by direct and indirect pathway projection neurons." Journal of Neuroscience 33(47): 18531–18539.

Freund, T. F., J. F. Powell, and A. D. Smith (1984). "Tyrosine hydroxylase-immunoreactive boutons in synaptic contact with identified striatonigral neurons, with particular reference

to dendritic spines." Neuroscience 13(4): 1189–1215.

Friston, K. (2005). "A theory of cortical responses." Philosophical Transactions of the Royal Society of London B: Biological Sciences 360(1456): 815–836.

Friston, K. (2008). "Hierarchical models in the brain." PLOS Computational Biology 4(11): e1000211.

Friston, K. (2009). "The free-energy principle: a rough guide to the brain?" Trends in Cognitive Sciences 13(7): 293–301.

Friston, K. (2011). "What is optimal about motor control?" Neuron 72(3): 488–498.

Friston, K. (2013). "Life as we know it." Journal of the Royal Society Interface 10(86): 20130475.

Friston, K. (2017). "Precision psychiatry." Biological Psychiatry: Cognitive Neuroscience and Neuroimaging 2(8): 640–643.

Friston, K. (2019a). "A free energy principle for a particular physics." arXiv preprint arXiv:1906.10184.

Friston, K. (2019b). "Waves of prediction." PLOS Biology 17(10): e3000426.

Friston, K., R. Adams, L. Perrinet, and M. Breakspear (2012). "Perceptions as hypotheses: saccades as experiments." Frontiers in Psychology 3(151).

Friston, K., and G. Buzsaki (2016). "The functional anatomy of time: what and when in the brain." Trends in Cognitive Sciences 20(7): 500–511.

Friston, K., L. Da Costa, D. Hafner, C. Hesp, and T. Parr (2020). "Sophisticated inference." arXiv preprint arXiv:2006.04120.

Friston, K., J. Daunizeau, and S. J. Kiebel (2009). "Reinforcement learning or Active Inference?" PLOS ONE 4(7): e6421.

Friston, K., J. Daunizeau, J. Kilner, and S. J. Kiebel (2010). "Action and behavior: a free-energy formulation." Biological Cybernetics 102(3): 227–260.

Friston, K., T. FitzGerald, F. Rigoli, P. Schwartenbeck, J. O'Doherty, and G. Pezzulo (2016). "Active Inference and learning." Neuroscience and Biobehavioral Reviews 68: 862–879.

Friston, K., T. FitzGerald, F. Rigoli, P. Schwartenbeck, and G. Pezzulo (2017). "Active Inference: a process theory." Neural Computation 29(1): 1–49.

Friston, K., and C. D. Frith (2015a). "Active inference, communication and hermeneutics( )." Cortex: A Journal Devoted to the Study of the Nervous System and Behavior 68: 129–143.

Friston, K., and C. Frith (2015b). "A duet for one." Consciousness and Cognition 36: 390–405.

Friston, K., and I. Herreros (2016). "Active Inference and learning in the cerebellum." Neural Computation 28(9): 1812–1839.

Friston, K., and S. Kiebel (2009). "Predictive coding under the free-energy principle." Philosophical Transactions of the Royal Society B: Biological Sciences 364(1521): 1211.

Friston, K., M. Levin, B. Sengupta, and G. Pezzulo (2015). "Knowing one's place: a free-energy approach to pattern regulation." Journal of the Royal Society Interface 12(105): 20141383.

Friston, K., M. Lin, C. D. Frith, G. Pezzulo, J. A. Hobson, and S. Ondobaka (2017). "Active Inference, curiosity and insight." Neural Computation 29(10): 2633–2683.

Friston, K., V. Litvak, A. Oswal, A. Razi, K. E. Stephan, B. C. M. van Wijk, G. Ziegler, and P. Zeidman (2016). "Bayesian model reduction and empirical Bayes for group (DCM) studies." NeuroImage 128(Supplement C): 413–431.

Friston, K., J. Mattout, and J. Kilner (2011). "Action understanding and active inference." Biological Cybernetics 104(1): 137–160.

Friston, K., J. Mattout, N. Trujillo-Barreto, J. Ashburner, and W. Penny (2007). "Variational free energy and the Laplace approximation." NeuroImage 34(1): 220–234.

Friston, K., T. Parr, and B. de Vries (2017). "The graphical brain: belief propagation and Active Inference." Network Neuroscience 1(4): 381–414.

Friston, K., T. Parr, Y. Yufik, N. Sajid, C. J. Price, and E. Holmes (2020). "Generative models, linguistic communication and active inference." Neuroscience and Biobehavioral Reviews 118: 42–64.

Friston, K., T. Parr, and P. Zeidman (2018). "Bayesian model reduction." arXiv preprint arXiv:1805.07092.

Friston, K., F. Rigoli, D. Ognibene, C. Mathys, T. Fitzgerald, and G. Pezzulo (2015). "Active Inference and epistemic value." Cognitive Neuroscience 6(4): 187–214.

Friston, K., R. Rosch, T. Parr, C. Price, and H. Bowman (2017). "Deep temporal models and active inference." Neuroscience and Biobehavioral Reviews 77: 388–402.

Friston, K., S. Samothrakis and R. Montague (2012). "Active Inference and agency: optimal control without cost functions." Biological Cybernetics 106(8–9): 523–541.

Friston, K., P. Schwartenbeck, T. FitzGerald, M. Moutoussis, T. Behrens, and R. J. Dolan (2014). "The anatomy of choice: dopamine and decision-making." Philosophical Transactions of the Royal Society B: Biological Sciences 369(1655): 20130481.

Friston, K., K. Stephan, B. Li, and J. Daunizeau (2010). "Generalised filtering." Mathematical Problems in Engineering. doi:10.1155/2010/621670.

Friston, K., K. E. Stephan, R. Montague, and R. J. Dolan (2014). "Computational psychiatry: the brain as a phantastic organ." Lancet Psychiatry 1(2): 148–158.

Frith, C. D., S. Blakemore, and D. M. Wolpert (2000). "Explaining the symptoms of schizophrenia: abnormalities in the awareness of action." Brain Research Reviews 31(2–3): 357–363.

Funahashi, S., C. J. Bruce, and P. S. Goldman-Rakic (1989). "Mnemonic coding of visual space in the monkey's dorsolateral prefrontal cortex." Journal of Neurophysiology 61(2): 331.

Fuster, J. n. M. (2004). "Upper processing stages of the perception-action cycle." Trends in Cognitive Sciences 8(4): 143–145.

Galea, J. M., S. Bestmann, M. Beigi, M. Jahanshahi, and J. C. Rothwell (2012). "Action reprogramming in Parkinson's disease: response to prediction error is modulated by levels of dopamine." Journal of Neuroscience 32(2): 542.

George, D., W. Lehrach, K. Kansky, M. Lázaro-Gredilla, C. Laan, B. Marthi, X. Lou, Z. Meng, Y. Liu, H. Wang, A. Lavin, and D. S. Phoenix (2017). "A generative vision model that trains with high data efficiency and breaks text-based CAPTCHAs." Science 358(6368): eaag2612.

Gershman, S. J., E. J. Horvitz, and J. B. Tenenbaum (2015). "Computational rationality: a converging paradigm for intelligence in brains, minds, and machines." Science 349(6245): 273.

Gertler, T. S., C. S. Chan, and D. J. Surmeier (2008). "Dichotomous anatomical properties of adult striatal medium spiny neurons." Journal of Neuroscience 28(43): 10814.

Gil, Z., B. W. Connors, and Y. Amitai (1997). "Differential regulation of neocortical synapses by neuromodulators and activity." Neuron 19(3): 679–686.

Goodfellow, I. J., J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio (2014). "Generative adversarial networks." arXiv:1406.2661 [cs, stat].

Gottlieb, J., P.-Y. Oudeyer, M. Lopes, and A. Baranes (2013). "Information-seeking, curiosity, and attention: computational and neural mechanisms." Trends in Cognitive Sciences 17(11): 585–593.

Gottwald, S., and D. A. Braun (2020). "The two kinds of free energy and the Bayesian revolution." arXiv:2004.11763 [cs, q-bio].

Gregory, R. L. (1980). "Perceptions as hypotheses." Philosophical Transactions of the Royal Society of London B: Biological Sciences 290(1038): 181–197.

Ha, D., and D. Eck (2017). "A neural representation of sketch drawings." arXiv preprint arXiv:1704.03477.

Ha, D., and J. Schmidhuber (2018). "World models." arXiv:1803.10122 [cs, stat].

Haeusler, S., and W. Maass (2007). "A statistical analysis of information-processing properties of lamina-specific cortical microcircuit models." Cerebral Cortex 17(1): 149–162.

Harlow, H. F. (1949). "The formation of learning sets." Psychological Review 56(1): 51–65.

Helmholtz, H. v. (1866). "Concerning the perceptions in general." Treatise on Physiological Optics. Translated by J. P. C. Southall. New York, Dover.

Helmholtz, H. v. (1867). Handbuch der physiologischen Optik. Leipzig: L. Voss.

Herbart, J. (1825). Psychologie als Wissenschaft: Neu gegründet auf Erfahrung, Metaphysik und Mathematik. Zweiter, analytischer Teil. Koenigsberg, Germany: August Wilhem Unzer.

Hezemans, F. H., N. Wolpe, and J. B. Rowe (2020). "Apathy is associated with reduced precision of prior beliefs about action outcomes." Journal of Experimental Psychology: General 149(9): 1767–1777.

Hills, T. T., P. M. Todd, D. Lazer, A. D. Redish, and I. D. Couzin (2015). "Exploration versus exploitation in space, mind, and society." Trends in Cognitive Sciences 19(1): 46–54.

Hillyard, S. A., E. K. Vogel, and S. J. Luck (1998). "Sensory gain control (amplification) as a mechanism of selective attention: electrophysiological and neuroimaging evidence." Philosophical Transactions of the Royal Society B: Biological Sciences 353(1373): 1257–1270.

Hinton, G. E. (2007a). "Learning multiple layers of representation." Trends in Cognitive Sciences 11(10): 428–434.

Hinton, G. E. (2007b). "To recognize shapes, first learn to generate images." Progress in Brain Research 165: 535–547.

Hoffmann, J. (1993). Vorhersage und Erkenntnis: Die Funktion von Antizipationen in der menschlichen Verhaltenssteuerung und Wahrnehmung [Anticipation and cognition: The function of anticipations in human behavioral control and perception]. Goettingen, Germany: Hogrefe.

Hoffmann, J. (2003). "Anticipatory behavioral control." In Anticipatory Behavior in Adaptive Learning Systems: Foundations, Theories, and Systems, edited by M. V. Butz, O. Sigaud, and P. Gerard, 44–65. Berlin: Springer-Verlag.

Hohwy, J. (2013). The Predictive Mind. New York: Oxford University Press.

Hohwy, J. (2016). "The self-evidencing brain." Noûs 50(2): 259–285.

Hommel, B., J. Musseler, G. Aschersleben, and W. Prinz (2001). "The theory of event coding (TEC): a framework for perception and action planning." Behavioral and Brain Science 24(5): 849–878.

Huerta, R., and M. Rabinovich (2004). "Reproducible sequence generation in random neural ensembles." Physical Review Letters 93(23): 238104.

Hurley, S. (2008). "The shared circuits model (SCM): how control, mirroring, and simulation can enable imitation, deliberation, and mindreading." Behavioral and Brain Sciences 31: 1–22.

Huygens, C. (1673). Horologium Oscillatorium: Sive, De Motu Pendulorum Ad Horologia Aptato Demostrationes Geometricae. Culture et Civilisation.

Iodice, P., G. Porciello, I. Bufalari, L. Barca, and G. Pezzulo (2019). "An interoceptive illusion of effort induced by false heart-rate feedback." Proceedings of the National Academy of Sciences 116(28): 13897–13902.

Isomura, T., and K. Friston (2018). "In vitro neural networks minimise variational free energy." Scientific Reports 8(1): 16926.

Isomura, T., T. Parr, and K. Friston (2019). "Bayesian filtering with multiple internal models: toward a theory of social intelligence." Neural Computation 31(12): 2390–2431.

James, W. (1890). The Principles of Psychology. New York: Dover Publications.

Jaynes, E. T. (1957). "Information theory and statistical mechanics." Physical Review 106(4): 620.

Jeannerod, M. (2001). "Neural simulation of action: a unifying mechanism for motor cognition." NeuroImage 14: S103–S109.

Joffily, M., and G. Coricelli (2013). "Emotional valence and the free-energy principle." PLOS Computational Biology 9(6): e1003094.

Kahneman, D. (2017). Thinking, fast and slow. United Kingdom: Penguin Books.

Kakade, S., and P. Dayan (2002). "Dopamine: generalization and bonuses." Neural Networks 15(4): 549–559.

Kanai, R., Y. Komura, S. Shipp, and K. Friston (2015). "Cerebral hierarchies: predictive processing, precision and the pulvinar." Philosophical Transactions of the Royal Society B: Biological Sciences 370(1668): 20140169.

Kaplan, R., and K. J. Friston (2018). "Planning and navigation as Active Inference." Biological Cybernetics 112: 323–343.

Kappen, H. J., V. Gómez, and M. Opper (2012). "Optimal control as a graphical model inference problem." Machine Learning 87(2): 159–182.

Karson, C. N. (1983). "Spontaneous eye-blink rates and dopaminergic systems." Brain 106(3): 643–653.

Kemp, C., and J. B. Tenenbaum (2008). "The discovery of structural form." Proceedings of the National Academy of Sciences 105(31): 10687–10692.

Kiebel, S. J., J. Daunizeau, and K. J. Friston (2008). "A hierarchy of time-scales and the brain." PLOS Computational Biology 4(11): e1000209.

Kingma, D. P., and M. Welling (2014). "Auto-encoding variational Bayes." arXiv:1312.6114 [cs, stat].

Kirchhoff, M., T. Parr, E. Palacios, K. Friston, and J. Kiverstein (2018). "The Markov blankets of life: autonomy, active inference and the free energy principle." Journal of the Royal Society, Interface 15, 20170792, doi:10.1098/rsif.2017.0792.

Knill, D. C., and A. Pouget (2004). "The Bayesian brain: The role of uncertainty in neural coding and computation." Trends in Neurosciences 27(12): 712–719.

Kording, K. P., and D. M. Wolpert (2006). "Bayesian decision theory in sensorimotor control." Trends in Cognitive Sciences 10: 319–326.

Koss, M. C. (1986). "Pupillary dilation as an index of central nervous system α2-adrenoceptor activation." Journal of Pharmacological Methods 15(1): 1–19.

Krakauer, J. W., A. A. Ghazanfar, A. Gomez-Marin, M. A. MacIver, and D. Poeppel (2017). "Neuroscience needs behavior: correcting a reductionist bias." Neuron 93(3): 480–490.

Krishnamurthy, K., M. R. Nassar, S. Sarode, and J. I. Gold (2017). "Arousal-related adjustments of perceptual biases optimize perception in dynamic environments." Nature Human Behaviour 1: 0107.

Kunde, W., I. Koch, and J. Hoffmann (2004). "Anticipated action effects affect the selection, initiation and execution of actions." Quarterly Journal of Experimental Psychology. Section A: Human Experimental Psychology 57(1): 87–106.

Lake, B. M., T. D. Ullman, J. B. Tenenbaum, and S. J. Gershman (2017). "Building machines that learn and think like people." Behavioral and Brain Sciences 40: 1–72.

Lambe, E. K., P. S. Goldman-Rakic, and G. K. Aghajanian (2000). "Serotonin induces EPSCs preferentially in layer V pyramidal neurons of the frontal cortex in the rat." Cerebral Cortex 10(10): 974–980.

Lavín, C., R. San Martín, and E. Rosales Jubal (2013). "Pupil dilation signals uncertainty and surprise in a learning gambling task." Frontiers in Behavioral Neuroscience 7: 218.

Lavine, N., M. Reuben, and P. Clarke (1997). "A population of nicotinic receptors is associated with thalamocortical afferents in the adult rat: laminal and areal analysis." Journal of Comparative Neurology 380(2): 175–190.

Lee, M. D., and E.-J. Wagenmakers (2014). Bayesian Cognitive Modeling: A Practical Course. Cambridge: Cambridge University Press.

Lee, S. W., S. Shimojo, and J. P. O'Doherty (2014). "Neural computations underlying arbitration between model-based and model-free learning." Neuron 81(3): 687–699.

Levine, S. (2018). "Reinforcement learning and control as probabilistic inference: tutorial and review." arXiv:1805.00909 [cs, stat].

Liao, H.-I., M. Yoneya, S. Kidani, M. Kashino, and S. Furukawa (2016). "Human pupillary dilation response to deviant auditory stimuli: effects of stimulus properties and voluntary attention." Frontiers in Neuroscience 10: 43.

Limanowski, J., and K. Friston (2019). "Attentional modulation of vision versus proprioception during action." Cerebral Cortex 30(3): 1637–1648.

Lindley, D. V. (1956). "On a measure of the information provided by an experiment." Annals of Mathematical Statistics 27(4): 986–1005.

Linson, A., T. Parr, and K. J. Friston (2020). "Active Inference, stressors, and psychological trauma: a neuroethological model of (mal)adaptive explore-exploit dynamics in ecological context." Behavioural Brain Research 380: 1–13.

Loeliger, H. A. (2004). "An introduction to factor graphs." IEEE Signal Processing Magazine 21(1): 28–41.

Loeliger, H. A., J. Dauwels, J. Hu, S. Korl, L. Ping, and F. R. Kschischang (2007). "The factor graph approach to model-based signal processing." Proceedings of the IEEE 95(6): 1295–1322.

MacKay, D. M. (1956). The Epistemological Problem for Automata. Princeton, NJ: Princeton University Press.

Maisto, D., L. Barca, O. V. d. Bergh, and G. Pezzulo (2021). "Perception and misperception of bodily symptoms from an Active Inference perspective: modelling the case of panic disorder." Psychological Review.

Maisto, D., K. Friston, and G. Pezzulo (2019). "Caching mechanisms for habit formation in Active Inference." Neurocomputing 359: 298–314.

Marek, R., C. Strobel, T. W. Bredy, and P. Sah (2013). "The amygdala and medial prefrontal cortex: partners in the fear circuit." Journal of Physiology 591(10): 2381–2391.

Marshall, L., C. Mathys, D. Ruge, A. O. de Berker, P. Dayan, K. E. Stephan, and S. Bestmann (2016). "Pharmacological fingerprints of contextual uncertainty." PLOS Biology 14(11): e1002575.

Maturana, H. R., and F. J. Varela (1980). Autopoiesis and Cognition: The Realization of Living. Dordrecht, Holland: D. Reidel.

Mesulam, M. M. (1998). "From sensation to cognition." Brain: Journal of Neurology 121(pt. 6): 1013–1052.

Miller, E. K., and J. D. Cohen (2001). "An integrative theory of prefrontal cortex function." Annual Review of Neuroscience 24: 167–202.

Miller, G. A., E. Galanter, and K. H. Pribram (1960). Plans and the Structure of Behavior. New York: Holt, Rinehart and Winston.

Miller, K. D. (2003). "Understanding layer 4 of the cortical circuit: a model based on cat V1." Cerebral Cortex 13(1): 73–82.

Millidge, B. (2019). "Deep Active Inference as variational policy gradients." arXiv:1907.03876 [cs].

Mirza, M. B., R. A. Adams, C. Mathys, and K. J. Friston (2018). "Human visual exploration reduces uncertainty about the sensed world." PLOS ONE 13(1): e0190429.

Mirza, M. B., R. A. Adams, C. D. Mathys, and K. J. Friston (2016). "Scene construction, visual foraging, and Active Inference." Frontiers in Computational Neuroscience 10(56).

Mirza, M. B., R. A. Adams, T. Parr, and K. Friston (2019). "Impulsivity and Active Inference." Journal of Cognitive Neuroscience 31(2): 202–220.

Montague, P. R., R. J. Dolan, K. J. Friston, and P. Dayan (2012). "Computational psychiatry." Trends in Cognitive Sciences 16(1): 72–80.

Moran, R. J., P. Campo, M. Symmonds, K. E. Stephan, R. J. Dolan, and K. J. Friston (2013). "Free energy, precision and learning: the role of cholinergic neuromodulation." Journal of Neuroscience 33(19): 8227–8236.

Moss, J., and J. P. Bolam (2008). "A dopaminergic axon lattice in the striatum and its relationship with cortical and thalamic terminals." Journal of Neuroscience 28(44): 11221.

Moutoussis, M., N. J. Trujillo-Barreto, W. El-Deredy, R. J. Dolan, and K. J. Friston (2014). "A formal model of interpersonal inference." Frontiers in Human Neuroscience 8: 160.

Mukherjee, P., A. Sabharwal, R. Kotov, A. Szekely, R. Parsey, D. M. Barch, and A. Mohanty (2016). "Disconnection between amygdala and medial prefrontal cortex in psychotic disorders." Schizophrenia Bulletin 42(4): 1056–1067.

Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective. Cambridge, MA: MIT Press.

Nambu, A. (2004). "A new dynamic model of the cortico-basal ganglia loop." Progress in Brain Research 143: 461–466.

Nassar, M. R., K. M. Rumsey, R. C. Wilson, K. Parikh, B. Heasly, and J. I. Gold (2012). "Rational regulation of learning dynamics by pupil-linked arousal systems." Nature Neuroscience 15(7): 1040–1046.

Nave, K., G. Deane, M. Miller, and A. Clark (2020). "Wilding the predictive brain." Cognitive Science 11(6): e1542.

Neisser, U. (2014). Cognitive Psychology: Classic Edition. London: Taylor & Francis.

Nishimoto, R., and J. Tani (2009). "Development of hierarchical structures for actions and motor imagery: a constructivist view from synthetic neuro-robotics study." Psychological Research PRPF 73(4): 545–558.

Olsen, S. R., D. S. Bortone, H. Adesnik, and M. Scanziani (2012). "Gain control by layer six in cortical circuits of vision." Nature 483: 47.

Ortega, P. A., and D. A. Braun (2013). "Thermodynamics as a theory of decision-making with information-processing costs." Proceedings of the Royal Society A: Mathematical, Physical and Engineering Science 469(2153).

Oudeyer, P. Y., F. Kaplan, and V. Hafner (2007). "Intrinsic motivation systems for autonomous mental development." IEEE Transactions on Evolutionary Computation 11(2): 265–286.

Palacios, E. R., T. Isomura, T. Parr, and K. Friston (2019). "The emergence of synchrony in networks of mutually inferring neurons." Scientific Reports 9(1): 6412.

Palacios, E. R., A. Razi, T. Parr, M. Kirchhoff, and K. Friston (2020). "On Markov blankets and hierarchical self-organisation." Journal of Theoretical Biology 486: 110089.

Pareés, I., H. Brown, A. Nuruki, R. A. Adams, M. Davare, K. P. Bhatia, K. Friston, and M. J. Edwards (2014). "Loss of sensory attenuation in patients with functional (psychogenic) movement disorders." Brain 137(11): 2916–2921.

Parr, T. (2020). "Inferring what to do (and what not to)." Entropy 22(5): 536.

Parr, T., D. A. Benrimoh, P. Vincent, and K. J. Friston (2018). "Precision and false perceptual inference." Frontiers in Integrative Neuroscience 12: 39–39.

Parr, T., L. D. Costa, and K. Friston (2020). "Markov blankets, information geometry and stochastic thermodynamics." Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences 378(2164): 20190159.

Parr, T., and K. J. Friston (2017a). "The computational anatomy of visual neglect." Cerebral Cortex 28: 1–14.

Parr, T., and K. J. Friston (2017b). "Uncertainty, epistemics and active inference." Journal of the Royal Society Interface 14(136).

Parr, T., and K. J. Friston (2017c). "Working memory, attention, and salience in Active Inference." Scientific Reports 7(1): 14678.

Parr, T., and K. J. Friston (2018a). "Active Inference and the anatomy of oculomotion." Neuropsychologia 111: 334–343.

Parr, T., and K. J. Friston (2018b). "The anatomy of inference: generative models and brain structure." Frontiers in Computational Neuroscience 12(90).

Parr, T., and K. J. Friston (2018c). "The discrete and continuous brain: From decisions to movement—and back again." Neural Computation 30(9): 2319–2347.

Parr, T., and K. J. Friston (2018d). "Generalised free energy and Active Inference: can the future cause the past?" bioRxiv.

Parr, T., and K. J. Friston (2019a). "Attention or salience?" Current Opinion in Psychology 29: 1–5.

Parr, T., and K. J. Friston (2019b). "The computational pharmacology of oculomotion." Psychopharmacology 236(8): 2473–2484.

Parr, T., D. Markovic, S. J. Kiebel, and K. J. Friston (2019). "Neuronal message passing using mean-field, Bethe, and marginal approximations." Scientific Reports 9(1): 1889.

Parr, T., M. B. Mirza, H. Cagnan, and K. J. Friston (2019). "Dynamic causal modelling of active vision." Journal of Neuroscience 39(32): 6265–6275.

Parr, T., R. V. Rikhye, M. M. Halassa, and K. J. Friston (2019). "Prefrontal computation as Active Inference." Cerebral Cortex 30(2): 682–695.

Pearl, J. (1988). Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. San Francisco, CA: Morgan Kaufmann.

Pearl, J. and D. Mackenzie (2018). The Book of Why: The New Science of Cause and Effect. New York: Basic Books.

Perrinet, L. U., R. A. Adams, and K. J. Friston (2014). "Active Inference, eye movements and oculomotor delays." Biological Cybernetics 108(6): 777–801.

Peters, A., B. S. McEwen, and K. Friston (2017). "Uncertainty and stress: why it causes diseases and how it is mastered by the brain." Progress in Neurobiology. 156: 164–188

Petersen, K. B., and M. S. Pedersen (2012). The Matrix Cookbook. https://www.math .uwaterloo.ca/~hwolkowi/matrixcookbook.pdf.

Pezzulo, G. (2012). "An Active Inference view of cognitive control." Frontiers in Theoretical and Philosophical Psychology 478: 1–2

Pezzulo, G. (2013). "Why do you fear the bogeyman? An embodied predictive coding model of perceptual inference." Cognitive, Affective, and Behavioral Neuroscience 14(3): 902–911.

Pezzulo, G., G. Baldassarre, M. V. Butz, C. Castelfranchi, and J. Hoffmann (2007). "Fron action to goals and vice-versa: Theoretical analysis and models of the ideomotor principle and TOTE." In Anticipatory Behavior in Adaptive Learning Systems, edited by M. V. Butz, O. Sigaud, G. Pezzulo, and G. Baldassarre. ABiALS 2006. Lecture Notes in Computer Science, vol 4520. Berlin: Springer. https://doi.org/10.1007/978-3 -540-74262-3_5.

Pezzulo, G., L. W. Barsalou, A. Cangelosi, M. H. Fischer, K. McRae, and M. J. Spivey (2013). "Computational grounded cognition: a new alliance between grounded cognition and computational modeling." Frontiers in Psychology 3: 612.

Pezzulo, G., E. Cartoni, F. Rigoli, L. Pio-Lopez, and K. Friston (2016). "Active Inference, epistemic value, and vicarious trial and error." Learning and Memory 23(7): 322–338.

Pezzulo, G., and P. Cisek (2016). "Navigating the affordance landscape: feedback control as a process model of behavior and cognition." Trends in Cognitive Sciences 20(6): 414–424.

Pezzulo, G., F. Donnarumma, P. Iodice, D. Maisto, and I. Stoianov (2017). "Model-based approaches to active perception and control." Entropy 19(6): 266.

Pezzulo, G., C. Kemere, and M. A. A. van der Meer (2017). "Internally generated hippocampal sequences as a vantage point to probe future-oriented cognition." Annals of the New York Academy of Sciences 1396(1): 144–165.

Pezzulo, G., and M. Levin (2015). "Re-membering the body: applications of computational neuroscience to the top-down control of regeneration of limbs and other complex organs." Integrative Biology 7(12): 1487–1517.

Pezzulo, G., B. Lw, A. Cangelosi, M. H. Fischer, K. McRae, and M. Spivey (2011). "The mechanics of embodiment: A dialogue on embodiment and computational modeling." Frontiers in Cognition 2(5): 1–21.

Pezzulo, G., D. Maisto, L. Barca, and O. V. d. Bergh (2019). "Symptom perception from a predictive processing perspective." Clinical Psychology in Europe 1(4): 1–14.

Pezzulo, G., and F. Rigoli (2011). "The value of foresight: how prospection affects decision-making." Frontiers in Neuroscience 5(79).

Pezzulo, G., F. Rigoli, and K. J. Friston (2015). "Active Inference, homeostatic regulation and adaptive behavioural control." Progress in Neurobiology 136: 17–35.

Pezzulo, G., F. Rigoli, and K. J. Friston (2018). "Hierarchical Active Inference: a theory of motivated control." Trends in Cognitive Sciences 22(4): 294–306.

Pezzulo, G., M. Zorzi, and M. Corbetta (2020). "The secret life of predictive brains: what's spontaneous activity for?" psyarxiv.

Pfeifer, R., and J. C. Bongard (2006). How the Body Shapes the Way We Think. Cambridge, MA: MIT Press.

Pio-Lopez, L., A. Nizard, K. Friston, and G. Pezzulo (2016). "Active Inference and robot control: a case study." Journal of the Royal Society Interface 13(122).

Posner, M. I., R. D. Rafal, L. S. Choate, and J. Vaughan (1985). "Inhibition of return: neural basis and function." Cognitive Neuropsychology 2(3): 211–228.

Pouget, A., J. M. Beck, W. J. Ma, and P. E. Latham (2013). "Probabilistic brains: knowns and unknowns." Nature Neuroscience 16(9): 1170–1178.

Powers, W. T. (1973). Behavior: The Control of Perception. Hawthorne, NY: Aldine.

Prosser, A., K. J. Friston, N. Bakker, and T. Parr (2018). "A Bayesian account of psychopathy: a model of lacks remorse and self-aggrandizing." Computational Psychiatry 1–49.

Ramstead, M. J. D., M. D. Kirchhoff, and K. J. Friston (2019). "A tale of two densities: Active Inference is enactive inference." Adaptive Behavior 28(4): 225–239.

Rao, R. P., and D. H. Ballard (1999). "Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects." Nature Neuroscience 2(1): 79–87.

Rawlik, K., M. Toussaint, and S. Vijayakumar (2013). "On stochastic optimal control and reinforcement learning by approximate inference." In Robotics: Science and Systems VIII, edited by N. Roy, P. Newman, and S. Srinivasa. Cambridge, MA: MIT Press.

Risken, H. (1996). "Fokker-Planck equation." The Fokker-Planck Equation: Methods of Solution and Applications, 63–95. Berlin: Springer.

Rizzolatti, G., L. Riggio, I. Dascola, and C. Umiltá (1987). "Reorienting attention across the horizontal and vertical meridians: evidence in favor of a premotor theory of attention." Neuropsychologia 25(1, pt. 1): 31–40.

Rosenblueth, A., N. Wiener, and J. Bigelow (1943). "Behavior, purpose and teleology." Philosophy of Science 10(1): 18–24.

Sahin, M., W. D. Bowen, and J. P. Donoghue (1992). "Location of nicotinic and muscarinic cholinergic and μ-opiate receptors in rat cerebral neocortex: evidence from thalamic and cortical lesions." Brain Research 579(1): 135–147.

Sales, A. C., K. J. Friston, M. W. Jones, A. E. Pickering, and R. J. Moran (2019). "Locus coeruleus tracking of prediction errors optimises cognitive flexibility: an Active Inference model." PLOS Computational Biology 15(1): e1006267.

Sancaktar, C., M. van Gerven, and P. Lanillos (2020). "End-to-end pixel-based deep Active Inference for body perception and action." arXiv:2001.05847 [cs, q-bio].

Schmidhuber, J. (1991). "Adaptive confidence and adaptive curiosity." Institut fur Informatik, Technische Universitat Munchen.

Schultz, W., P. Dayan, and P. R. Montague (1997). "A neural substrate of prediction and reward." Science 275(5306): 1593.

Schwartenbeck, P., T. H. B. FitzGerald, C. Mathys, R. Dolan, and K. Friston (2015). "The dopaminergic midbrain encodes the expected certainty about desired outcomes." Cerebral Cortex 25(10): 3434–3445.

Schwartenbeck, P., T. H. B. FitzGerald, C. Mathys, R. Dolan, F. Wurst, M. Kronbichler, and K. Friston (2015). "Optimal inference with suboptimal models: Addiction and active Bayesian inference." Medical Hypotheses 84(2): 109–117.

Schwartenbeck, P., and K. Friston (2016). "Computational phenotyping in psychiatry: a worked example." eNeuro 3(4): eneuro.0049–0016.2016.

Schwartenbeck, P., J. Passecker, T. U. Hauser, T. H. FitzGerald, M. Kronbichler, and K. J. Friston (2019). "Computational mechanisms of curiosity and goal-directed exploration." eLife 8: e41703.

Schwöbel, S., S. Kiebel, and D. Marković (2018). "Active Inference, belief propagation, and the Bethe approximation." Neural Computation 30(9): 1–38.

Seth, A. K. (2013). "Interoceptive inference, emotion, and the embodied self." Trends in Cognitive Sciences 17(11): 565–573.

Seth, A. K., and K. J. Friston (2016). "Active interoceptive inference and the emotional brain." Philosophical Transactions of the Royal Society B 371(1708): 20160007.

Seth, A. K., K. Suzuki, and H. D. Critchley (2012). "An interoceptive predictive coding model of conscious presence." Frontiers in Psychology 2: 1–16.

Shadmehr, R., M. A. Smith, and J. W. Krakauer (2010). "Error correction, sensory prediction, and adaptation in motor control." Annual Review of Neuroscience 33: 89–108.

Sheliga, B. M., L. Riggio, and G. Rizzolatti (1994). "Orienting of attention and eye movements." Experimental Brain Research 98(3): 507–522.

Sheliga, B. M., L. Riggio, and G. Rizzolatti (1995). "Spatial attention and eye movements." Experimental Brain Research 105(2): 261–275.

Shipp, S. (2007). "Structure and function of the cerebral cortex." Current Biology 17(12): R443–R449.

Shipp, S. (2016). "Neural elements for predictive coding." Frontiers in Psychology 7: 1792.

Shipp, S., R. A. Adams, and K. J. Friston (2013). "Reflections on agranular architecture: predictive coding in the motor cortex." Trends in Neurosciences 36(12): 706–716.

Simon, H. A. (1990). "Bounded rationality." In Utility and Probability, 15–18. New York: Springer.

Skinner, B. F. (1938). The Behavior of Organisms: An Experimental Analysis. New York: Appleton-Century-Crofts.

Smith, R., R. D. Lane, T. Parr, and K. J. Friston (2019). "Neurocomputational mechanisms underlying emotional awareness: insights afforded by deep Active Inference and their potential clinical relevance." Neuroscience and Biobehavioral Reviews 107: 473–491.

Smith, R., T. Parr, and K. J. Friston (2019). "Simulating emotions: an Active Inference model of emotional state inference and emotion concept learning." bioRxiv 640813.

Solway, A., and M. M. Botvinick (2012). "Goal-directed decision making as probabilistic inference: a computational framework and potential neural correlates." Psychological Review 119(1): 120–154.

Sterling, P. (2012). "Allostasis: a model of predictive regulation." Physiology and Behavior 106(1): 5–15.

Stewart, N., N. Chater, and G. D. A. Brown (2006). "Decision by sampling." Cognitive Psychology 53(1): 1–26.

Stoianov, I., D. Maisto, and G. Pezzulo (2020). "The hippocampal formation as a hierarchical generative model supporting generative replay and continual learning." bioRxiv 2020.2001.2016.908889.

Sutton, R. S., and A. G. Barto (1998). Reinforcement Learning: An Introduction. Cambridge MA: MIT Press.

Tani, J., and J. White (2020). "Cognitive neurorobotics and self in the shared world, a focused review of ongoing research." Adaptive Behavior. 1–20.

Tenenbaum, J. B., T. L. Griffiths, and C. Kemp (2006). "Theory-based Bayesian models of inductive learning and reasoning." Trends in Cognitive Sciences 10: 309–318.

Tervo, D. G. R., J. B. Tenenbaum, and S. J. Gershman (2016). "Toward the neural implementation of structure learning." Current Opinion in Neurobiology 37: 99–105.

Thomson, A. (2010). "Neocortical layer 6, a review." Frontiers in Neuroanatomy 4(13).

Todorov, E. (2004). "Optimality principles in sensorimotor control." Nature Neuroscience 7(9): 907–915.

Todorov, E. (2008). "General duality between optimal control and estimation." In 47th IEEE Conference on Decision and Control, 4286–4292.

Todorov, E. (2009). "Efficient computation of optimal actions." Proceedings of the National Academy of Sciences USA 106(28): 11478–11483.

Tolman, E. C. (1948). "Cognitive maps in rats and men." Psychological Review 55: 189–208.

Tschantz, A., L. Barca, D. Maisto, C. L. Buckley, A. K. Seth, and G. Pezzulo (2021). "Simulating homeostatic, allostatic and goal-directed forms of interoceptive control using Active Inference." bioRxiv 2021.2002.2016.431365.

Tschantz, A., A. K. Seth, and C. L. Buckley (2020). "Learning action-oriented models through active inference." PLOS Computational Biology 16(4): e1007805.

Tsvetanov, K. A., R. N. A. Henson, L. K. Tyler, A. Razi, L. Geerligs, T. E. Ham, and J. B. Rowe (2016). "Extrinsic and intrinsic brain network connectivity maintains cognition across the lifespan despite accelerated decay of regional brain activation." Journal of Neuroscience 36(11): 3115.

Ueltzhöffer, K. (2018). "Deep Active Inference." Biological Cybernetics 112(6): 547–573.

Ungerleider, L. G., and J. V. Haxby (1994). " 'What' and 'where' in the human brain." Current Opinion in Neurobiology 4(2): 157–165.

van de Laar, T. W., and B. de Vries (2019). "Simulating Active Inference processes by message passing." Frontiers in Robotics and AI 6(20).

Veissière, S. P. L., A. Constant, M. J. D. Ramstead, K. J. Friston, and L. J. Kirmayer (2020). "Thinking through other minds: a variational approach to cognition and culture." Behavioral and Brain Sciences 43: e90.

Verschure, P., C. M. A. Pennartz, and G. Pezzulo (2014). The why, what, where, when and how of goal-directed choice: neuronal and computational principles. Philosophical Transactions of the Royal Society of London B: Biological Sciences 369: 20130483.

Verschure, P. F. M. J. (2012). "Distributed adaptive control: a theory of the mind, brain, body nexus." Biologically Inspired Cognitive Architectures 1: 55–72.

Verschure, P. F. M. J., T. Voegtlin, and R. J. Douglas (2003). "Environmentally mediated synergy between perception and behaviour in mobile robots." Nature 425(6958): 620–624.

Vincent, P., T. Parr, D. Benrimoh, and K. J. Friston (2019). "With an eye on uncertainty: modelling pupillary responses to environmental volatility." PLOS Computational Biology 15(7): e1007126.

Vossel, S., M. Bauer, C. Mathys, R. A. Adams, R. J. Dolan, K. E. Stephan, and K. J. Friston (2014). "Cholinergic stimulation enhances Bayesian belief updating in the deployment of spatial attention." Journal of Neuroscience 34(47): 15735.

Wainwright, M. J., and M. I. Jordan (2008). "Graphical models, exponential families, and variational inference." Foundations and Trends in Machine Learning 1(1–2): 1–305.

Wald, A. (1947). "An essentially complete class of admissible decision functions." Annals of Mathematical Statistics 18(4): 549–555.

Wall, N. R., M. De La Parra, E. M. Callaway, and A. C. Kreitzer (2013). "Differential innervation of direct- and indirect-pathway striatal projection neurons." Neuron 79(2): 347–360.

Wesson, D. W., and D. A. Wilson (2011). "Sniffing out the contributions of the olfactory tubercle to the sense of smell: hedonics, sensory integration, and more?" Neuroscience and Biobehavioral Reviews 35(3): 655–668.

Wiener, N. (1948). Cybernetics: or Control and Communication in the Animal and the Machine. Cambridge, MA: MIT Press.

Winn, J., and C. M. Bishop (2005). "Variational message passing." Journal of Machine Learning Research 6(April): 661–694.

Wolpert, D. M., K. Doya, and M. Kawato (2003). "A unifying computational framework for motor control and social interaction." Philosophical Transactions of the Royal Society of London B: Biological Sciences 358(1431): 593–602.

Wolpert, D. M., and M. Kawato (1998). "Multiple paired forward and inverse models for motor control." Neural Networks 11(7–8): 1317–1329.

Wolpert, D. M., and M. S. Landy (2012). "Motor control is decision-making." Current Opinion in Neurobiology 22(6): 996–1003.

Yager, L. M., A. F. Garcia, A. M. Wunsch, and S. M. Ferguson (2015). "The ins and outs of the striatum: role in drug addiction." Neuroscience 301: 529–541.

Yamashita, Y., and J. Tani (2008). "Emergence of functional hierarchy in a multiple timescale neural network model: a humanoid robot experiment." PLOS Computational Biology 4(11): e1000220.

Yuan, R., and P. Ao (2012). "Beyond Itô versus Stratonovich." Journal of Statistical Mechanics: Theory and Experiment 2012(07): P07010.

Yuille, A., and D. Kersten (2006). "Vision as Bayesian inference: analysis by synthesis?" Probabilistic Models of Cognition 10(7): 301–308.

Zeki, S., and S. Shipp (1988). "The functional logic of cortical connections." Nature 335(6188): 311–317.

Zénon, A., O. Solopchuk, and G. Pezzulo (2019). "An information-theoretic perspective on the costs of cognition." Neuropsychologia 123: 5–18.

Zhang, Z., S. Cordeiro Matos, S. Jego, A. Adamantidis, and P. Séguéla (2013). "Norepinephrine drives persistent activity in prefrontal cortex via synergistic α1 and α2 adrenoceptors." PLOS ONE 8(6): e66122.

Zhou, Y., P. Zeidman, S. Wu, A. Razi, C. Chen, L. Yang, J. Zou, G. Wang, H. Wang, and K. J. Friston (2018). "Altered intrinsic and extrinsic connectivity in schizophrenia." NeuroImage: Clinical 17: 704–716.

原书索引

以下保留原书英文索引的顺序、全部词条及印刷页码，附中文译名. **这里的页码是原书页码，不是本译本页码**；冻结源 PDF 相应物理页为印刷页加 11. 译本术语首次出现位置另见最后的术语索引.

中文	原文	原书页码
准确度	Accuracy	28
异稳态调节	Allostasis	215–216
模糊度	Ambiguity	33, 137
注意	Attention	157, 217
基底神经节	Basal ganglia	92–93
贝叶斯脑	Bayesian brain	200
贝叶斯惊异	Bayesian surprise	20
贝叶斯规则	Bayes' rule	16–17
鸟鸣	Birdsong	164
有限理性	Bounded rationality	213
复杂度	Complexity	28, 220
皮层微环路	Cortical microcircuit	87–88
Dirichlet 分布	Dirichlet distribution	142
多巴胺	Dopamine	92
情绪	Emotion	213–214
能量	Energy	28, 55
熵	Entropy	28
Euler–Lagrange 方程	Euler-Lagrange equations	55, 237
期望	Expectation	21
期望自由能	Expected free energy	33, 52, 73, 144, 251–252
因子图	Factor graph	67–68
自由能（或变分自由能）	Free energy (or variational free energy)	27–28
运动广义坐标	Generalized coordinates of motion	69–70, 78–79, 235
广义同步	Generalized synchrony	164
生成对抗网络	Generative adversarial networks	222
生成模型	Generative model	8, 16–17, 22–23, 63
生成过程	Generative process	22–23
目标导向行为	Goal-directed behaviour	93, 101
习惯	Habits	93, 209
Hamilton 量	Hamiltonian	47, 54–55
层级	Hierarchy	148
混杂模型	Hybrid models	166
观念运动理论	Ideomotor theory	202
信息增益	Information gain	33, 135

中文	原文	原书页码
内感受推断	Interoceptive inference	215–216
Jensen 不等式	Jensen's inequality	64–65
Kullback–Leibler 散度	Kullback-Leibler divergence	20, 66
Laplace 近似	Laplace approximation	81, 233–235
学习	Learning	142, 161, 247
Lorenz 系统	Lorenz systems	163
Lotka–Volterra 系统	Lotka-Volterra systems	159
马尔可夫毯	Markov blanket	43–45, 55
元贝叶斯方法	Meta-Bayesianism	176
微环路	Microcircuit	87–88
动机	Motivation	36, 101, 187, 213–214
导航	Navigation	146
神经递质	Neurotransmitters	97–98
牛顿动力学	Newtonian dynamics	54, 155
非平衡稳态	Nonequilibrium steady state	48, 240
新奇性	Novelty	144, 252
Occam 剃刀	Occam's razor	28
最优控制理论	Optimal control theory	204
最优性	Optimality	22, 208
参数经验贝叶斯（PEB）	Parametric empirical Bayes (PEB)	178–179
Parkinson 病	Parkinson's disease	94
部分可观测马尔可夫决策过程	Partially observed Markov decision process	69–70, 243–247
知觉控制理论	Perceptual control theory	203
规划	Planning	31–33
实用价值	Pragmatic value	33
精确度	Precision	138, 157
预测编码	Predictive coding	78–83, 89, 201
过程理论	Process theory	85–86, 197
随机动力系统	Random dynamical system	48, 54, 238–239
阅读	Reading	148–149
反射	Reflexes	155
强化学习	Reinforcement learning	53, 203, 206, 208–209
风险	Risk	33
眼跳	Saccades	139, 167–168
显著性	Salience	144
自我证成	Self-evidencing	41, 47, 52, 239
感觉衰减	Sensory attenuation	157
社会动力学	Social dynamics	164–165, 221
惊异	Surprise	19, 39

中文	原文	原书页码
突触效能	Synaptic efficacy	95
Taylor 级数	Taylor series	69, 232–233
丘脑	Thalamus	94–95
价值函数	Value function	53
变分自编码器	Variational autoencoders	222
变分推断	Variational inference	51
变分 Laplace	Variational Laplace	177
变分消息传递	Variational message passing	75–76, 237–238, 254
工作记忆	Working memory	112, 196

术语索引

中文术语	英文术语	页码
中型棘状神经元	medium spiny neurons	65
神经调质作用	neuromodulation	67
时间深度	temporal depth	78
异稳态调节	allostasis	81
形态计算	morphological computation	84
隐马尔可夫模型	hidden Markov model，HMM	86
新奇性	novelty	98