CS 6804：世界模型

五份课件中文译本（审校候选）

Chris Thomas
Virginia Tech，计算机科学系

2026 年秋季课程课件 · Virginia Tech · 2026
Model: gpt-6.1-terra / gpt-6.1-sol
审核：曹溪能
Updated: 2026-11-06

译本说明

本译本仅覆盖本地冻结的五份 PDF 课件，共 269 个源 PDF 物理页（50、65、54、29、71 页）。文件编号仅用于本译本导航，不据此认定官方讲次、完整课程目录或最新版本。内容权威为这五份源 PDF；源文件及 SHA-256 见随附来源清单。课程政策、日期和研究结论均为原课件在其标注时点的陈述，不作为当前课程安排或研究事实的独立核验。

先前初译所用模型尚未核实；已核验历史轮次使用 gpt-6.1-terra/high，2026-11-04 恢复修订及 2026-11-06 本轮作者恢复、自查和打包使用 gpt-6.1-sol/high。未反推其他轮次。封面固定审核字段依项目标准排版，不证明所列人员已经亲自审阅，也不代替独立审校或主控验收。

源课件中的疑似公式缺陷、记号冲突、未列条件及不可辨内容，以可见原文为准并作显式译注；不暗中补齐推导或推测图表数值。截图保留原出处，箭头节点数学结构提供可编辑重建。第三方图片及译文公开传播权利尚未核实，本次仅准备本地审校候选，未发布。原课件引用的外部论文、视频、网站与其他课程资源不属于这五份冻结 PDF 的正文交付范围。

目录

第 1 份课件：课程介绍 **2**

第 2 份课件：世界模型组件与后续主题 **17**

第 3 份课件：Transformer、无标签学习与强化学习 **68**

第 4 份课件：价值函数与深度 Q 学习 **107**

第 5 份课件：策略梯度、基于模型的强化学习与生成模型 **122**

第 1 份课件：课程介绍

原课件第 1 页：封面

CS 6804：世界模型

Chris Thomas
Virginia Tech 计算机科学系
2026 年秋季

课件来源说明：许多幻灯片改编自 Graumann、Kovashka、Lazebnik、Fouhey、Lowe、Seitz、Batra、Forsyth、Fei-Fei Li 和 Hoiem 的材料。

原课件第 2 页：课程信息

- 地点：Derring Hall 1084 室，926 West Campus Drive，Blacksburg，VA。
- 上课时间：周二和周四 12:30–13:45。
- 授课教师：Chris Thomas。
- 联系方式：请通过 Canvas 消息系统联系，不要发送电子邮件。
- 办公室：Data and Decision Sciences Building 378 室。
- 答疑时间：周二 14:00–15:00。Zoom 链接见教学大纲。
- 本课程没有助教。

原课件第 3 页：课程信息（续）

- 考试时段：12T；2026 年 12 月 11 日 10:05–12:05。
  - 本课程不设考试；期末项目展示和报告代替期末考试。
  - 如有必要，我们可能利用这一时段进行线上期末展示。
- 使用 Canvas 提交作业和发布成绩。

原课件第 4 页：提纲

- 课程安排
- 自我介绍
- 课程规定：评审、展示、项目
- 什么是世界模型
- 简史及 2026 年的发展现状
- 本课程提出的四个问题
- 路线图与主题投票

原课件第 5 页：关于我

Virginia Tech 助理教授，2022 年秋季入职。研究重点为多模态人工智能和计算多媒体理解，即视觉、语言、音频及其他模态。

研究涉及若干核心挑战：

- 对异构媒体进行细粒度推理；
- 确保人工智能输出可信，包括事实核查、幻觉检测和跨模态一致性；
- 提高对抗威胁下的可靠性，包括鲁棒性、防御、认证及真实场景中的安全性。

核心目标：开发可靠、可信、细粒度的多模态推理系统。

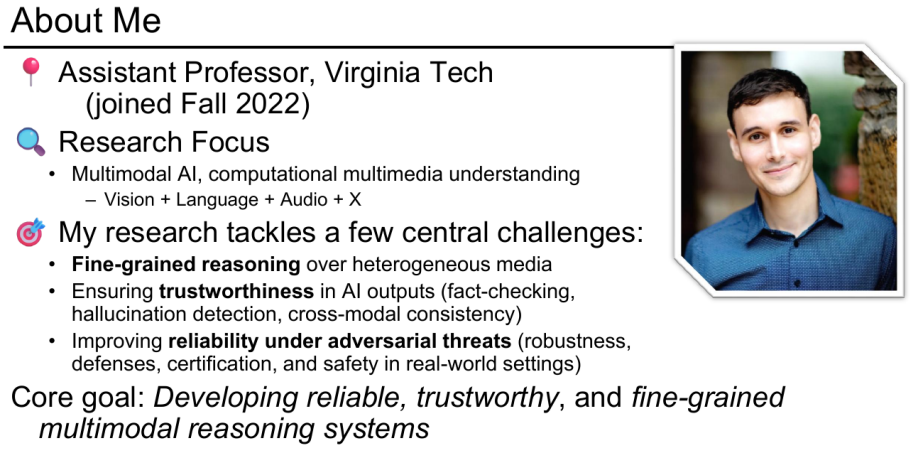

原课件第 6 页：部分研究主题

构建可信、细粒度且可靠的多模态人工智能，包含以下两个方向：

- 可信的细粒度多模态理解：细粒度语义对齐；多模态信息抽取和本体归纳；忠实且可靠的推理。
- 多模态模型的鲁棒性、安全与信任：从不可靠数据构建可信模型；对抗鲁棒性与认证；模型免疫与安全部署。

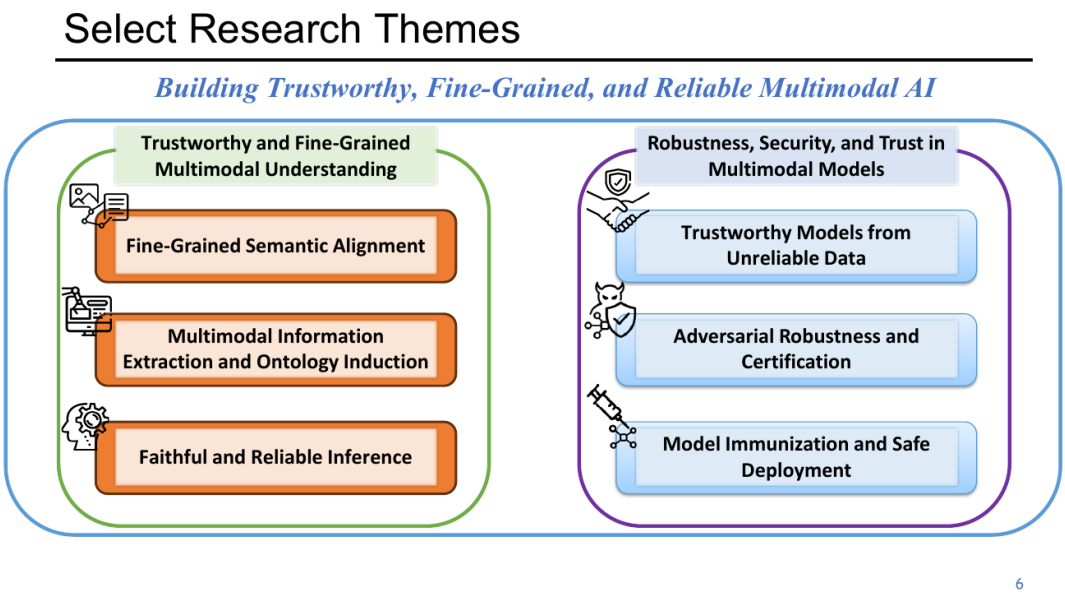

原课件第 7 页：自我介绍

- 你叫什么名字?
- 你属于哪个院系、哪个项目？读几年级?
- 请介绍你目前的研究：正在做什么，与哪位教师合作？如果目前没有开展研究，希望做什么?
- 为什么选修这门课?
- 有什么有趣的事情想让大家了解?

原课件第 8 页：提纲

- 课程安排
- 自我介绍
- 课程规定：评审、展示、项目
- 什么是世界模型
- 简史及 2026 年的发展现状
- 本课程提出的四个问题
- 路线图与主题投票

原课件第 9 页：课程结构

原页仅有标题。

原课件第 10 页：课程目标

- 了解世界模型领域的前沿方法。
- 学习对研究进行批判性思考；这一能力不限于本课程，包括批判性地评估所接触的研究论文，以及理解不同研究之间的联系。
- 学习构思新颖的想法和现有研究方法的扩展，并将这些想法付诸实现。
- 学习清晰地撰写和展示研究成果。
- 学习如何在研究团队中与他人工作和合作。

原课件第 11 页：我是否具备本课程所需的准备？

- 本课程涉及阅读、理解、撰写近期研究论文中的想法，并将其付诸实现。
- 强烈建议具备深度学习背景，并且此前使用过深度神经网络。
- 此前修过机器学习课程也非常有帮助。

原课件第 12 页：课程准备（续）

- 不要求你了解每篇论文中的每一项技术，但应当能够理解主要思想并提出扩展或改进。
- 接下来的三讲将复习强化学习。如果能够跟上，应当就没有问题。
- 如果担心自己能否完成课程，请尽早与我沟通。
- 课程日程仍需根据课堂展示的数量和学生感兴趣的主题确定。

原课件第 13 页：一堂典型的课

- 这是一门研讨课。课堂时间主要用于学生展示和讨论。
- 不设考试，也没有编程作业。
- 课前：阅读主要论文并撰写评审。
- 课上：先展示，然后由展示者组织讨论；离开前填写一份针对展示者的同伴评审。
- 整个学期中，每位学生进行一次论文展示，并参加一个贯穿学期的小组项目。
- 接下来的三讲由我讲授强化学习背景。
- 学生展示从 9 月 8 日持续到 11 月 19 日；最后三次课为项目展示。

原课件第 14 页：Canvas 与课程材料

- 所有课程相关内容均在 Canvas 上，包括教学大纲、课程日程、幻灯片、成绩和公告。所有材料均通过 Canvas 提交，包括评审、展示用幻灯片和项目交付物。
- 请开启 Canvas 电子邮件和 / 或推送通知，以便获知日程变更和评审任务。
- 请在 Canvas 上给我发消息，不要发送电子邮件。

原课件第 15 页：期末成绩的组成

- 期末项目：占总成绩 45%，其中项目提案 5%、项目进度报告 5%、项目展示 15%、项目最终报告 20%。
- 课堂参与和讨论：15%。
- 论文展示：20%。
- 论文评审：20%。

原课件第 16 页：出勤

- 这是一门研讨课，要求出勤。通过课堂上对每次展示进行的同伴评审记录出勤；评审仅在上课期间开放，当天未填写同伴评审即视为未出勤。
- 无正当理由缺课超过两次会对期末成绩产生负面影响。第二次缺课之后，再次缺课只有取得学生事务长办公室的证明才能获准。
- 如果生病，请不要来上课。请考虑班上其他同学，并与我联系，以便妥善处理缺课事宜。

原课件第 17 页：参与和讨论

- 每次上课前应仔细阅读指定论文，并准备好问题。
- 应向报告人提出有意义的问题，积极参与课堂。
- 以论文评审为参考参与讨论，评价论文的优点和缺点。
- 班上其他同学提出的问题是面向全班的；如果知道答案，其他同学应主动参与回答。
- 论文展示者应引导和主持讨论，不要出现冷场。

原课件第 18 页：论文评审

- 本课程要求学生批判性地评价和评审世界模型领域的研究论文。
- 每次有论文展示的课都须写一份论文评审。第一次展示是 9 月 8 日；展示者在自己展示的当天不必提交评审。

原课件第 19 页：论文评审（续）

- 必须评审其中一篇主要论文。在有两位展示者的日子里，系统会随机指定评审哪一篇；展示日程确定后，评审分配将公布在 Canvas 上。
- 在这些日子里，还须针对未分配给自己的那篇论文提交两个讨论问题。仍应阅读两篇主要论文，以便参与讨论。
- 篇幅为一页，单倍行距，11 磅 Times New Roman，页边距 1 英寸。
- 在论文展示课的前一天 23:59 前通过 Canvas 提交 PDF。关于如何写好评审，请参阅教学大纲链接中的 CVPR 审稿指南。

原课件第 20 页：论文评审的内容

- 摘要：说明论文试图解决什么问题及其提出的方法；概述主要创新和贡献，避免无关紧要的细节；例如概述新的模型架构或损失函数；说明如何进行实验评估及重要发现或结果。
- 与既有工作的关系：概述论文与既有工作的关系，以及其贡献为何重要或不重要。
- 优点：至少指出该方法的三个优点。
- 缺点：哪些方面削弱了论文的贡献？至少指出三个缺点。
- 未来工作：至少提出一种可能的扩展。可以针对你发现的缺点提出修正，例如修改模型或损失函数，也可以提出如何以新方式将论文技术用于其他任务；但不能仅改写或重复论文自身建议的未来工作。

原课件第 21 页：写好评审的建议

- 寻找论文中好的或有启发性的内容，以及它带来的知识进展。
- 突出工作的创新性和潜在影响。
- 最重要的是具体、详细：每条只有一句简短文字的项目列表不算详细评审。
- 阅读论文后，思考几天再动笔。

原课件第 22 页：写好评审的建议（续）

- 具体说明创新性；声称某事此前已做过，必须提供具体参考文献支持。
- 避免使用 “作者” 一词，而用 “论文” 或 “方法”。
- 积极提出新想法，例如一种技术、一个数据集、一种应用或一种推广方式。
- 我们希望听到你的想法，而不是作者的说法。

原课件第 23 页：论文评审的评分与迟交规定

- 按时提交的评审以 10 分为起点。错误陈述、含糊或无关的说法；不加入自己的见解而改写论文自身的摘要、优点或缺点；以及未涉及要求的部分，都会扣分。
- 截止时间是论文展示课前一天 23:59，以 Canvas 提交时间为准；迟交一分钟也算迟交。
- 课堂当天 10:00 前提交的评审以满分的一半（5 分）为起点；10:00 以后提交不得分。

原课件第 24 页：迟交规定（续）

- 每人有三次迟交宽限：三份评审可以在课堂当天 10:00 前提交而不受处罚。
- 这些宽限仅适用于论文评审。

原课件第 25 页：论文展示

- 每位学生进行一次论文展示，涵盖一篇主要论文，也可能包含若干背景论文。
- 多数日期只有一位展示者，部分日期有两位，取决于最终选课人数。可以在主题表中说明偏好，但不保证满足。
- 独自展示：报告 40 分钟，随后讨论 25 分钟。两人同一天展示：每人先报告 25 分钟，讨论 10 分钟，再由第二位展示者开始。

原课件第 26 页：论文展示（续）

- 无论哪种情况，你都要独自主持自己的讨论。学习引导讨论、临场应对问题，是本课程的重要目的。
- 报告可以比规定时间短，但最多只能短 2–3 分钟，绝不能超时。
- 请练习报告！应准备讨论主题并推动讨论。

原课件第 27 页：论文展示的最低要求

- 明确界定论文所解决的问题；说明该问题为何重要、有趣和 / 或有挑战性。
- 介绍试图解决这一问题或相关问题的先前工作。
- 详细描述针对该问题提出的方法，解释论文如何进行评估。
- 讨论论文的主要优点和缺点；提出未来工作设想并指出尚未解决的研究问题。

原课件第 28 页：论文展示的材料来源

- 可以自由使用网上的幻灯片和资源；作者常会公开自己的幻灯片，也可以查看会议网站。
- 但必须清楚引用所有来源并注明幻灯片出处！务必用自己的话表达，不要把论文原文照搬到幻灯片上。
- 你的展示要求与作者不同：应批判性地介绍论文。

原课件第 29 页：论文展示（续）

- 幻灯片不应只有大段文字；可用带动画的简短要点，其余内容口头解释。非常鼓励使用示意图、图像、视频和动态公式。
- 展示前一天 23:59 前，将幻灯片（pptx 或 PDF）上传至 Canvas。
- 带好笔记本电脑所需的连接设备，如 HDMI 线或显示转接器。无论是论文展示还是项目展示，确保能在教室展示都是你的责任。

原课件第 30 页：同伴评审与展示评分

每次展示后须在 Canvas 完成简短的同伴评审，评价展示者解释论文、回答问题和引导讨论的表现。评审在上课时开放、下课时关闭；完成评审即记录出勤。

展示成绩依据：表达的清晰度和展示质量；是否覆盖论文要点；陈述是否正确；是否满足各项要求；班上其他同学的同伴评审；主持讨论的表现；以及展示是否明显经过练习、是否符合时间要求。

原课件第 31 页：期末项目

- 由学生主导的小组项目，课程结束时提交报告。每组 3–5 人；较大的组面临更高要求，所有成员都必须作出显著贡献。
- 所有项目都必须实现一个世界模型，或其一个实质性组成部分，并进行充分评估。
- 目标是写出一份类似于已读过的会议论文的最终报告；理想情况下，项目能够成为会议论文。请本周开始组队。

原课件第 32 页：什么可以作为期末项目

项目必须属于以下三类之一：对课堂论文进行实质性扩展并充分实验评估；针对课堂讨论过或文献中已有的世界建模问题提出新方法并充分评估；或提出全新的世界建模问题，解释其重要性，实现一种方法并予以评估。

必须有自己的技术贡献。将现有方法用于新数据集或问题，若至少没有一定技术创新，并不足够；仅把现有方法用于新对象并报告结果，不构成一个持续整个学期的博士研讨课项目。所有项目均须进行充分的实验评估。

原课件第 33 页：项目交付物与日期

所有项目交付物均上传至 Canvas：

- 项目提案：占总成绩 5%，10 月 2 日 23:59 截止。
- 项目进度报告：占 5%，11 月 6 日 23:59 截止。
- 项目展示：占 15%，幻灯片在展示前一天 23:59 截止。
- 项目最终报告：占 20%，12 月 11 日 23:59 截止。
- 项目展示日期为 12 月 1 日、3 日和 8 日。

原课件第 34 页：项目提案和进度报告

- 提案：不含参考文献 3–5 页，使用 CVPR LaTeX 模板。包括标题、小组成员及组内安排；清晰的问题陈述；充分的文献综述，说明先前工作的不足；拟议方法的详细描述，包括新的损失函数或模型修改；计划使用的计算资源；实验方案、预期结果以及成功的判据。
- 进度报告：约 3–5 页，使用同一模板，包括引言、相关工作、方法和结果。可以复用提案中的文字；即使初步结果不理想也要写入。
- 最终报告：不含参考文献 8 页，包括摘要和五个标准部分。

原课件第 35 页：小组、贡献评议与迟交规定

- 每位学生记录自己的贡献以及工作如何分配，并对组内每一位其他成员的贡献提交评议。这是强制要求；未提交者将无法获得期末项目成绩。
- 搭便车者将受到严厉处罚。如果组内有搭便车成员，应尽快与我联系；没有联系的组将按该成员充分参与处理。

原课件第 36 页：项目迟交规定（续）

- 每组在三个交付物之间总共有三天迟交宽限，并非每个交付物各有三天。按天计算，迟交一分钟算一天。
- 宽限用尽后，每迟交一天，该交付物的得分乘以 0.5。最终报告迟交超过三天将不予评分。
- 这些宽限与论文评审的三天迟交宽限分开计算。

原课件第 37 页：学术诚信与生成式人工智能

- Virginia Tech 研究生荣誉准则适用于本课程的所有内容。鼓励与他人讨论课程内容，但论文评审必须独立完成且不得分享。
- 可以使用其他论文和网站的代码与材料，但须引用来源并清晰说明自己的贡献。

- 可以使用生成式 AI 理解论文、回答背景问题、协助项目代码或润色自己写的语言；不得用它生成工作的实质内容。例如上传论文并要求给出优缺点，再加以改写，属于违反荣誉准则。

原课件第 38 页：学术诚信与生成式人工智能（续）

- 如在任何作业中使用生成式 AI 工具，必须披露并提交完整交互记录：整段对话，而非摘要或自认为相关的部分。
- 对违规行为通常建议的处分是课程最终成绩 F*。
- 编造或歪曲引用属于学术不端；“是大语言模型做的” 不是免责理由。

原课件第 39 页：便利措施、紧急情况、复核成绩与 GPU

- 便利措施：联系残障学生服务处（540-231-3788，ssd@vt.edu，ssd.vt.edu）。如有 SSD 信函，请在学期中尽早通过电子邮件发给我；实施通常需要提前 5 个工作日通知。
- 紧急情况和健康问题：请在截止日期前通知我；如果确实不可能，则在之后尽快通知。可能需要学生事务长办公室的证明。
- 成绩复核：收到成绩后一周内通过 Canvas 消息提出；仅用于明显错误，而非细微的判断分歧。学期末最迟在最终成绩提交日中午 12:00 提出。

原课件第 40 页：便利措施、紧急情况、复核成绩与 GPU（续）

项目可使用 Google Colab、Virginia Tech Advanced Research Computing 和系里的集群 `glogin.cs.vt.edu`。设计项目时须考虑 GPU 限制。

原课件第 41 页：提纲

课程安排；自我介绍；课程规定（评审、展示、项目）；什么是世界模型；简史与 2026 年的发展现状；本课程提出的四个问题；路线图与主题投票。

原课件第 42 页：什么是世界模型？

下图为一位骑车者及其想象中的自行车。来源：Ha and Schmidhuber, *World Models*, NeurIPS 2018, Fig. 1（据 Scott McCloud 的 *Understanding Comics*）。

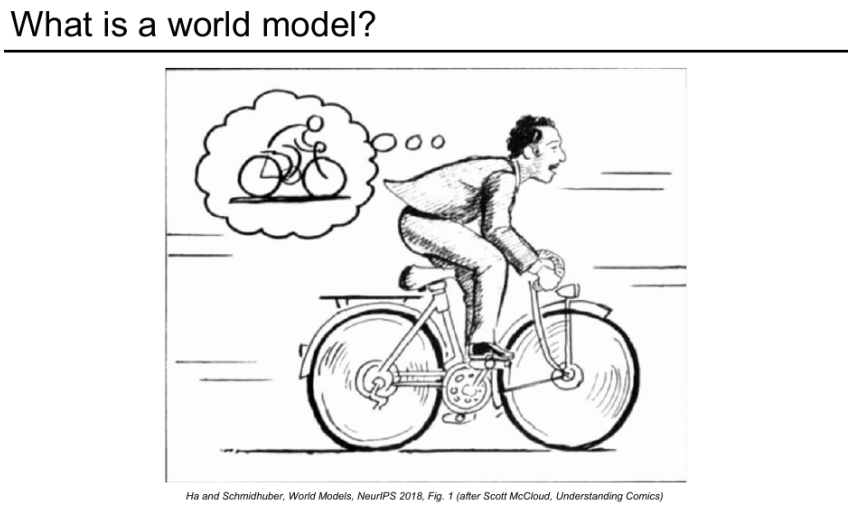

Ha and Schmidhuber, World Models, NeurIPS 2018, Fig. 1 (after Scott McCloud, Understanding Comics)

原课件第 43 页：接下来会发生什么？

下图展示两名处于空中的跳水者。来源：Oh, arXiv:2606.12783, Fig. 1。

Oh, arXiv:2606.12783, Fig. 1

原课件第 44 页：作出那项预测需要什么

- 你从未见过完全相同的场景。
- 你产生了多个而非一个可能的未来，并按合理程度排序。
- 你推断出了一个看不见的泳池。
- 你没有移动，也没有被告知目标，就做到了这一点。

原图中的提示语为：“告诉我下图中接下来一秒会发生什么。”回答称：大约一秒内，跳水者将完成旋转并入水；根据其目前在空中的抱膝 / 屈体姿势，看起来是在从跳台或跳板跳水。接下来的一秒，跳水者会完成旋转，伸展身体准备入水，双手以流线型姿势先入水，随后头部、躯干和

腿入水，并在穿过水面时溅起水花。回答认为其姿势有利于干净入水，暗示这是一次受控制、经过练习的跳水，而非随意一跳。来源：Oh, arXiv:2606.12783, Fig. 10。

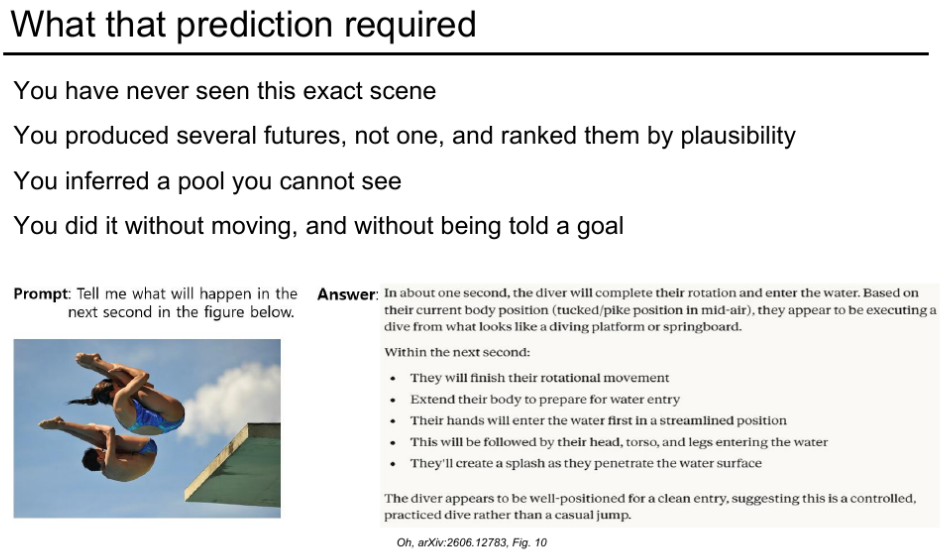

原课件第 45 页：一个定义

- 世界模型是对环境进行预测的学习模型。“学习”指从经验中拟合，而非手工编写；“预测”指输出未来状态，而非标签。
- 一些世界模型以动作为条件：预测取决于智能体做什么。这是基于模型的强化学习的设定，也适用于大多数机器人研究。
- 另一些模型不以动作为输入，预测场景如何继续；用互联网视频训练的视频预测模型没有动作通道。
- 模型是否接收动作是本课程中的主要设计选择之一。

原课件第 46 页：关于未来的三个层次的问题

原图区分关联、干预和反事实三个层次（来源：Oh, arXiv:2606.12783, Fig. 2）：

- 关联，$P(y \mid x)$：典型活动是观察。问题如“是什么？”“看到 X 会如何改变我对 Y 的信念？”例子：一种症状说明了什么疾病？一次调查对选举结果说明了什么？
- 干预，$P(y \mid do(x), z)$：典型活动是行动。问题如“如果……会怎样？”“如果我做 X 会怎样？”例子：如果服用阿司匹林，我的头痛会好吗？如果我们禁止香烟会怎样？
- 反事实，$P(y_x \mid x', y')$：典型活动是想象与回顾。问题如“为什么？”“是否是 X 导致了 Y？”“如果我采取不同的行动会怎样？”例子：我的头痛是阿司匹林止住的吗？如果 Oswald 没有枪击 Kennedy，他是否还活着？如果过去两年我没有吸烟会怎样？

Three levels of asking about the future

Level (Symbol)	Typical Activity	Typical Questions	Examples
1. Association $P(y\|x)$	Seeing	What is? How would seeing X change my belief in$Y$?	What does a symptom tell me about a disease? What does a survey tell us about the election results?
2. Intervention $P(y\|do(x), z)$	Doing	What if? What if I do X?	What if I take aspirin, will my headache be cured? What if we ban cigarettes?
3. Counterfactuals $P(y_x\|x', y')$	Imagining, Retrospection	Why? Was it X that caused Y? What if I had acted differently?	Was it the aspirin that stopped my headache? Would Kennedy be alive had Oswald not shot him? What if I had not been smoking the past 2 years?

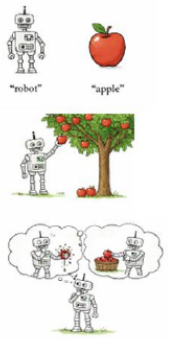

Oh, arXiv:2606.12783, Fig. 2

原课件第 47 页：强化学习（RL）

设定：智能体能够采取影响环境状态的动作，并偶尔观察到取决于状态的奖励。目标：学习一个策略（从状态到动作的映射），使随时间累积的期望奖励最大。

图中智能体向环境发送动作，环境向智能体返回后继状态和奖励。

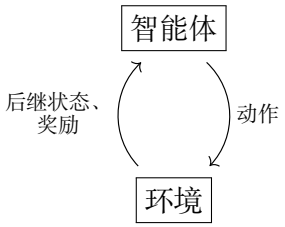

Reinforcement learning (RL)

- Setting: agent that can take *actions* affecting the *state* of the environment and observe occasional *rewards* that depend on the state
- Goal: learn a *policy* (mapping from states to actions) to maximize expected reward over time

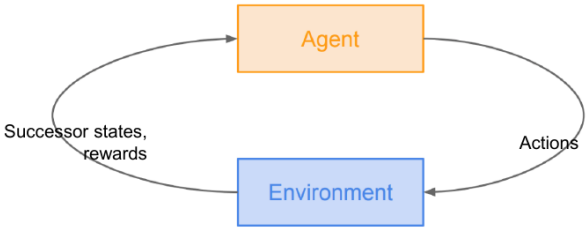

原课件第 48 页：需要熟悉的四个术语

- 状态：世界当前的样子。

- 动作：智能体所做的事。
- 奖励：衡量结果的标量分数。
- 策略：从状态到动作的函数。

原课件第 49 页：无模型学习需要真实交互

- 学习的每一部分都需要真实交互；交互缓慢、昂贵，有时还不安全。
- 改变奖励后就要重新开始。知识存在于策略之中，因而受任务塑形且不能复用。

译注：以上是原课件在此处的概括，不是关于所有无模型方法的普遍定理。已收集经验或预训练表示能否复用、奖励改变后是否需要重新训练，取决于具体算法、数据与任务。图示四项机器人任务：A1 四足行走、UR5 视觉拾取放置、XArm 视觉拾取放置和 Sphero 导航。来源：Wu, Escontrela, Hafner, Goldberg and Abbeel, *DayDreamer: World Models for Physical Robot Learning*, CoRL 2022, Fig. 1。

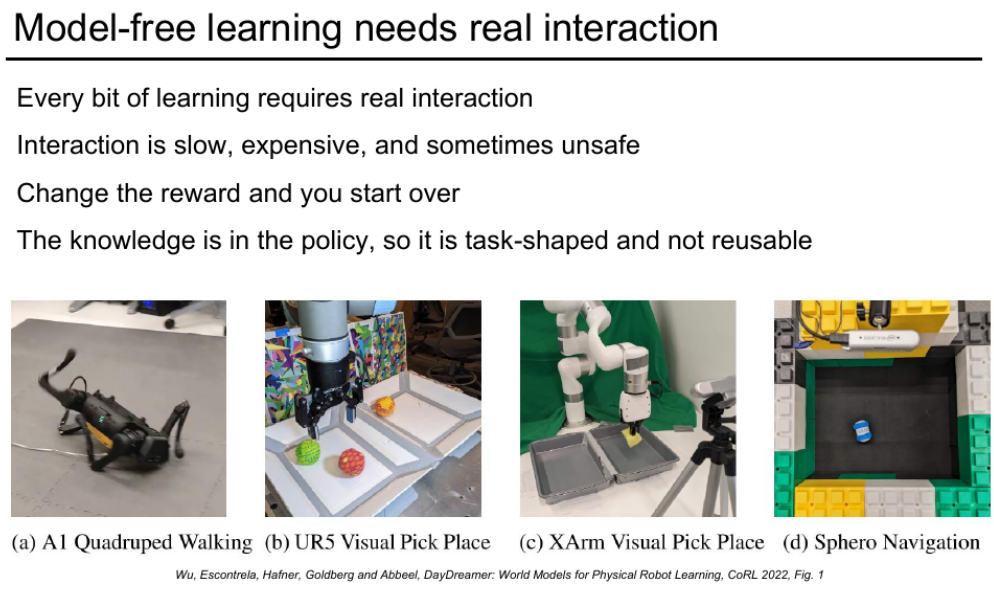

原课件第 50 页：把环境放进智能体内部

原图比较（a）智能体与环境直接交互和（b）智能体内部含世界模型 (E, H, F, D) 的结构；图中标出内部与外部、s_t, r_{t-1}、s_{t+1}, r_t 以及 $a_t \sim \pi(a_t \mid s_t)$。来源：Oh, arXiv:2606.12783, Fig. 3。

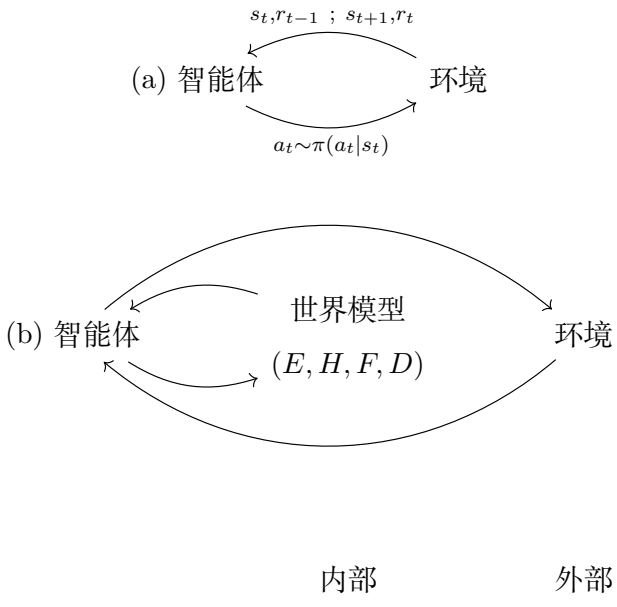

Put the environment inside the agent

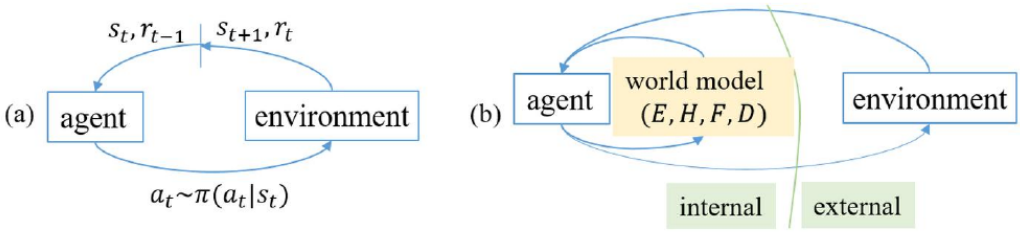

Oh, arXiv:2606.12783, Fig. 3

第 2 份课件：世界模型组件与后续主题

原课件第 1 页：封面

CS 6804：世界模型；Chris Thomas，Virginia Tech 计算机科学系，2026 年秋季。许多幻灯片改编自 Graumann、Kovashka、Lazebnik、Fouhey、Lowe、Seitz、Batra、Forsyth、Fei-Fei Li 和 Hoiem 的材料。

原课件第 2 页：提纲

上次停在智能体内部的模型。后续提纲：循环模型（普通 RNN、LSTM、GRU）；瓶颈与注意力；Transformer（自注意力、位置编码、视觉 Transformer）；无标签学习；强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 3 页：一个定义

世界模型是对环境进行预测的学习模型：从经验拟合而非手写，输出未来状态而非标签。一些模型以动作为条件，预测取决于智能体的行为，这是基于模型的强化学习及大多数机器人研究的设定；另一些模型无需动作输入，预测场景如何继续，例如以互联网视频训练的视频预测模型没有动作通道。是否接收动作是本课程将讨论的主要设计选择。

原课件第 4 页：强化学习

设定：智能体能采取影响环境状态的动作，并偶尔观察到依赖于状态的奖励。目标：学习从状态到动作的策略，使随时间的期望奖励最大化。原图中，智能体向环境发送动作，环境返回后继状态和奖励；参见第 1 份课件第 47 页的原图与译文。

原课件第 5 页：四个基本术语

状态是世界当前的样子；动作是智能体所做的事；奖励是衡量结果的标量分数；策略是从状态到动作的函数。

原课件第 6 页：把环境放进智能体内部

原图比较智能体与环境直接交互，以及智能体内部含世界模型 (E, H, F, D) 的结构，标出状态、奖励、动作以及内部和外部。来源：Oh, arXiv:2606.12783, Fig. 3；图与标签译文见第 1 份课件第 50 页。

原课件第 7 页：四个部分：E, H, F, D

本学期几乎每篇论文都会替换这四者之一、保留其余部分。是否使用 D 是一项设计选择。

图中从观测 x_t 出发，经编码器 E 得到 z_t，再经记忆模块 H 得到 h_t，经动力学模块 F 得到 $\hat{z}_t$，最后经解码器 D 得到重建 $\hat{x}_t$。图中 H 携带 h_{t-1}, z_{t-1}，动作 a_{t-1} 从此处进入。

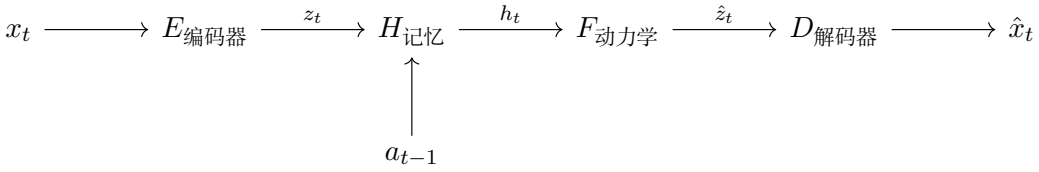

H 携带 h_{t-1}, z_{t-1}；左端为观测，右端为重建。

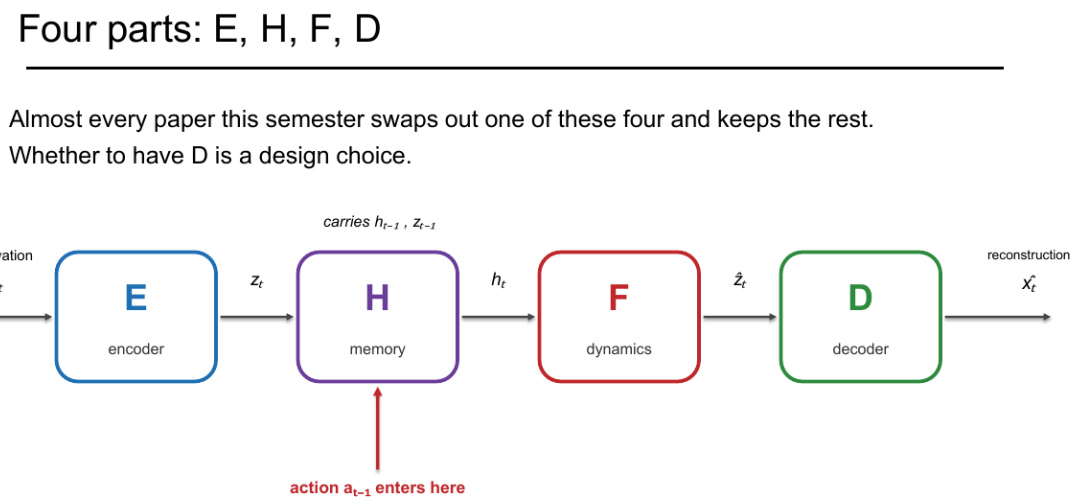

原课件第 8 页：F 的作用

- H 是记忆；F 知道时间和动作。
- F 体现了模型知道世界如何运行这一主张。
- 对本学期每篇论文，都思考：F 是什么？以什么为输入？在哪个空间中预测？

原图比较三种训练配置：第一幅仅标出世界模型 (E, D) 可学习；第二幅 (E, D) 冻结而 (H, F) 可学习；第三幅 (E, D)、(H, F) 均冻结而智能体策略 π 可学习。火焰表示可学习，雪花表示冻结。三幅均画出智能体、世界模型和外部环境之间的交互；来源：arXiv:2606.12783, Fig. 6。

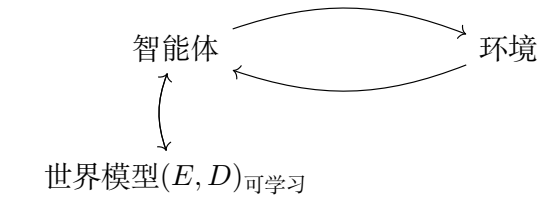

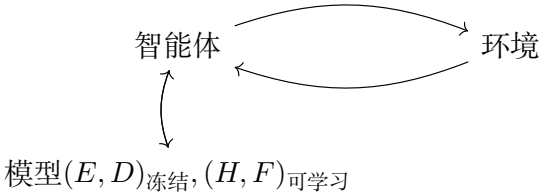

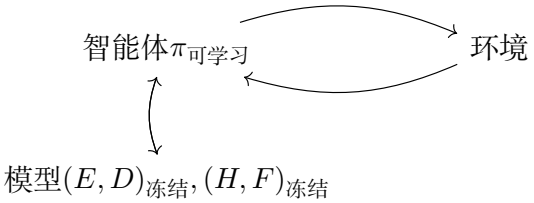

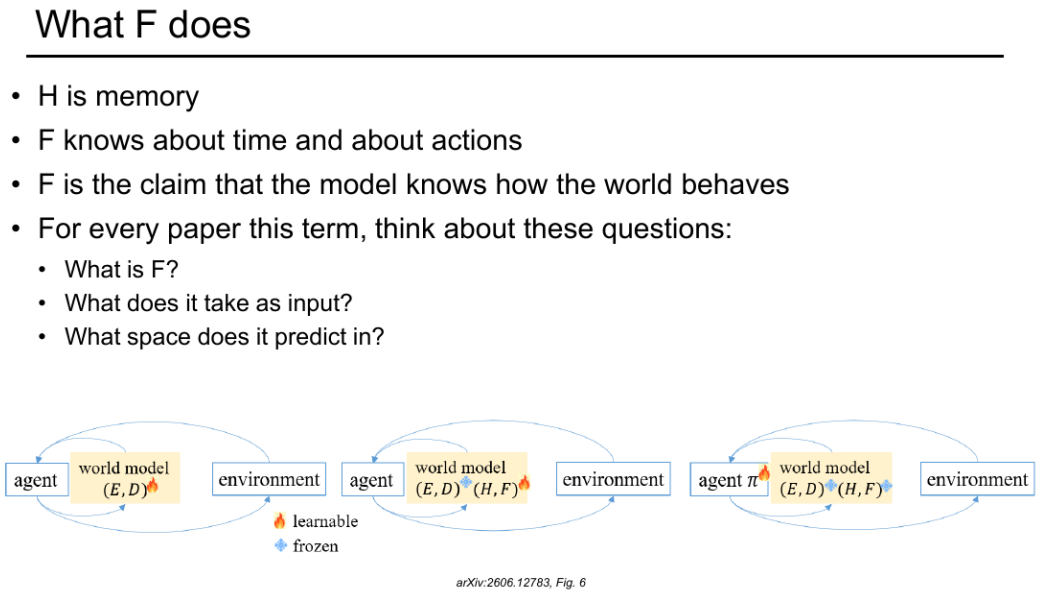

原课件第 9 页：展开：如何使用 F

将当前观测编码一次；然后预测下一个潜变量、选择动作、再次预测；在一个预测时域内重复，而不接触环境；只有希望查看时才解码。原图从 x_k 经 E 得到 z_k，与 h_k 一起进入 H 得到 h_{k+1}；后续 F 预测 $\hat{z}_{k+1}$，D 解码为 $\hat{x}_{k+1}$，并将预测潜变量送入下一次 H。之后重复至 $k+l$；图示动作依次为 $a_k \sim \pi(z_k, h_k)$、$a_{k+1} \sim \pi(z_{k+1}, h_{k+1})$、$a_{k+l-1} \sim \pi(z_{k+l-1}, h_{k+l-1})$。来源：arXiv:2606.12783, Fig. 4。

译注：原图策略参数写作不带帽的潜变量 z，相应预测节点写作带帽的 $\hat{z}$；此处分别保留，不推定两种记号是否有意区分。

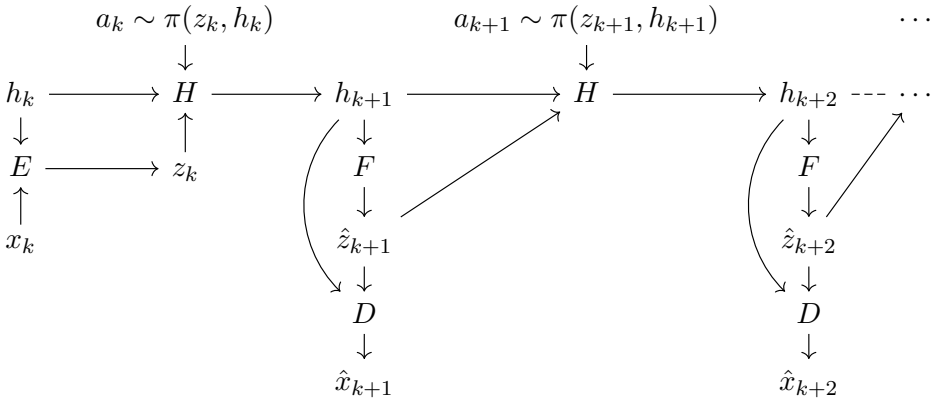

图中省略号后的末段完整标记为：

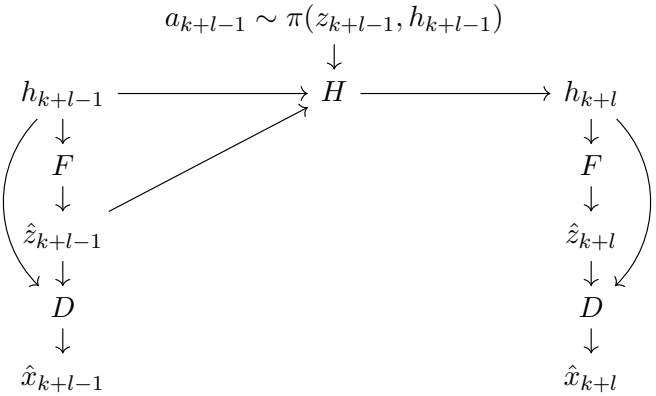

Rollout: what you do with F

- Encode the current observation, once
- Then predict the next latent, choose an action, predict again
- Repeat for a horizon, never touching the environment
- Decode only if you want to look at it

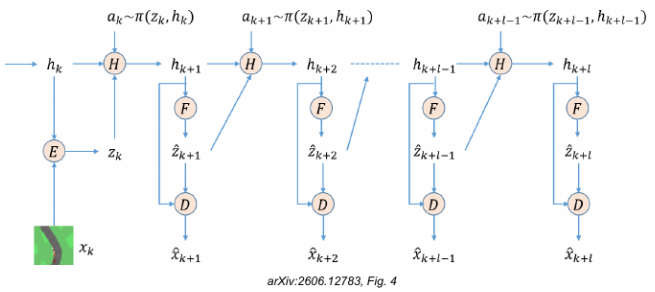

原课件第 10 页：为什么低成本展开很重要

- 样本效率：真实交互缓慢、昂贵，有时还会损坏机器人。
- 安全性：宁可在想象中发生碰撞。
- 复用：动力学不依赖于任务；学习一次世界如何运行，就可以在其中追求多个目标。

- 规划：可以搜索未来，而不只是对当前情况作出反应。

原图依次标注经验数据集、学得的潜在动力学、通过潜在空间想象学得的价值与动作。来源：Hafner, Lillicrap, Ba and Norouzi, *Dream to Control: Learning Behaviors by Latent Imagination*, ICLR 2020, Fig. 1。

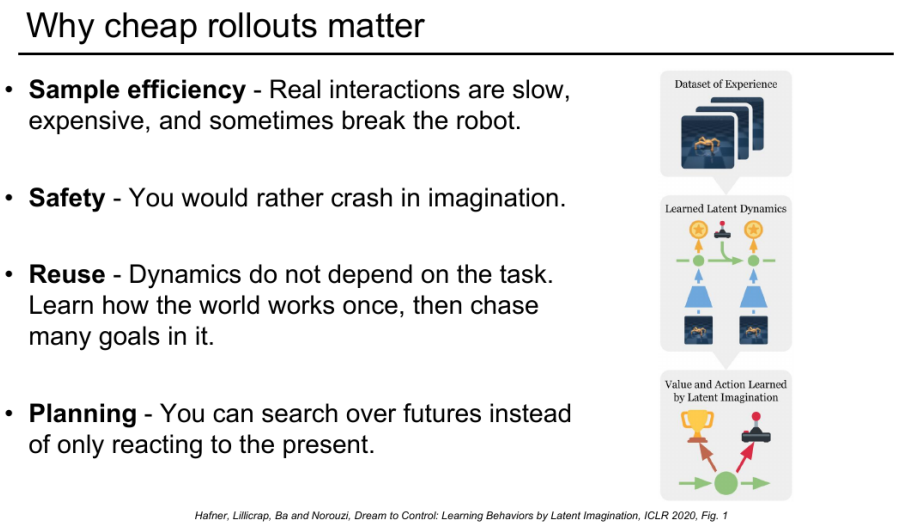

原课件第 11 页：DayDreamer，一小时训练出的四足机器人

DayDreamer（CoRL 2022）使用真实地面上的真实四足机器人，没有使用模拟器或任何仿真到现实的迁移。它在约一小时的真实世界经验中学会行走，大部分练习是在边运行边学习的模型内部进行的。课件称该模型结构与 Dreamer 相同，没有为了真实世界额外添加内容。

图示 Dreamer 使用模拟器、DayDreamer 使用真实世界；数据收集到回放缓冲区并采样用于世界模型，世界模型产生想象展开，行动者–评论家据此行动。来源：arXiv:2606.12783, Fig. 16。

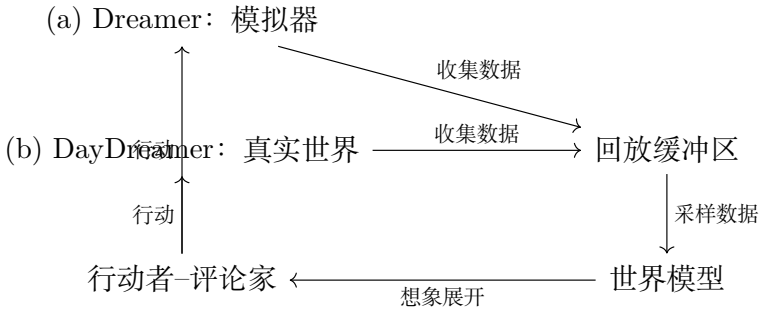

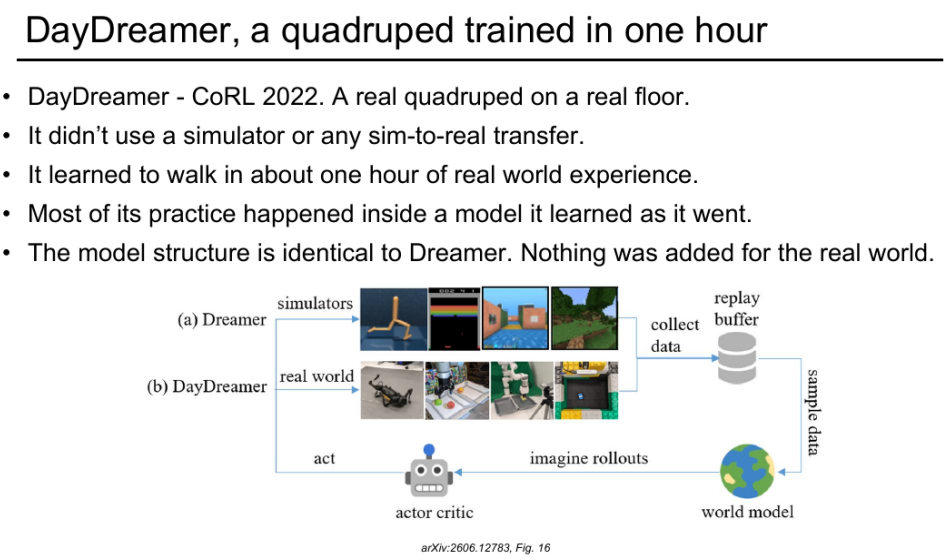

原课件第 12 页：DayDreamer 的一小时真实世界训练

A1 四足行走：从零开始训练一小时、得到的行走行为、适应推搡 10 分钟；原页画面选中第三项。视频：https://www.youtube.com/watch?v=m9u93_55jhQ。来源：Wu, Escontrela, Hafner, Goldberg and Abbeel, *DayDreamer*, CoRL 2022。

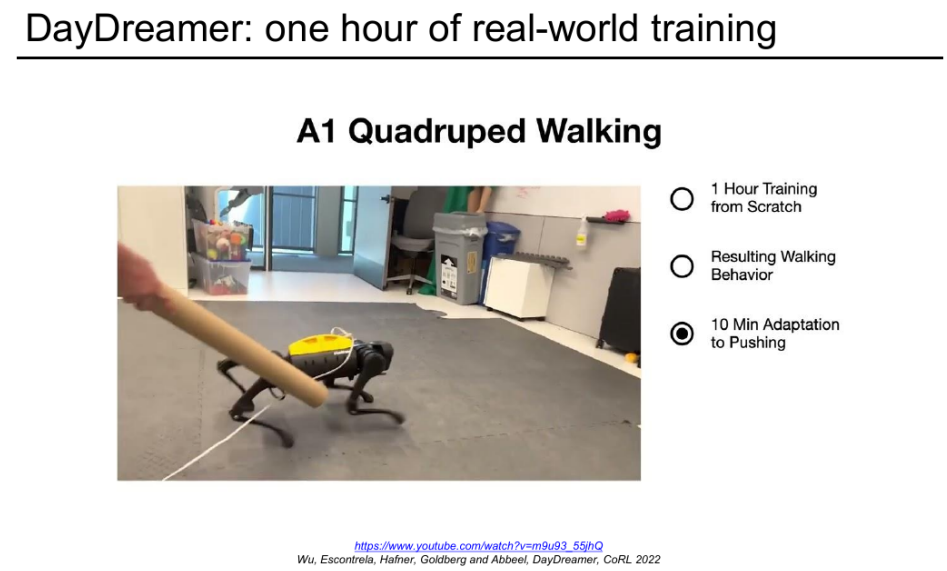

原课件第 13 页：展开过程中的误差累积

第一步之后，模型基于自己的预测继续预测；小误差进入下一步并不断增长。单步精度对于二十步精度几乎没有说明作用，因此想象时域是一个超参数。图中给出游戏画面序列。来源：Valevski, Leviathan, Arar and Fruchter, *Diffusion Models Are Real-Time Game Engines*, ICLR 2025, Fig. 4。

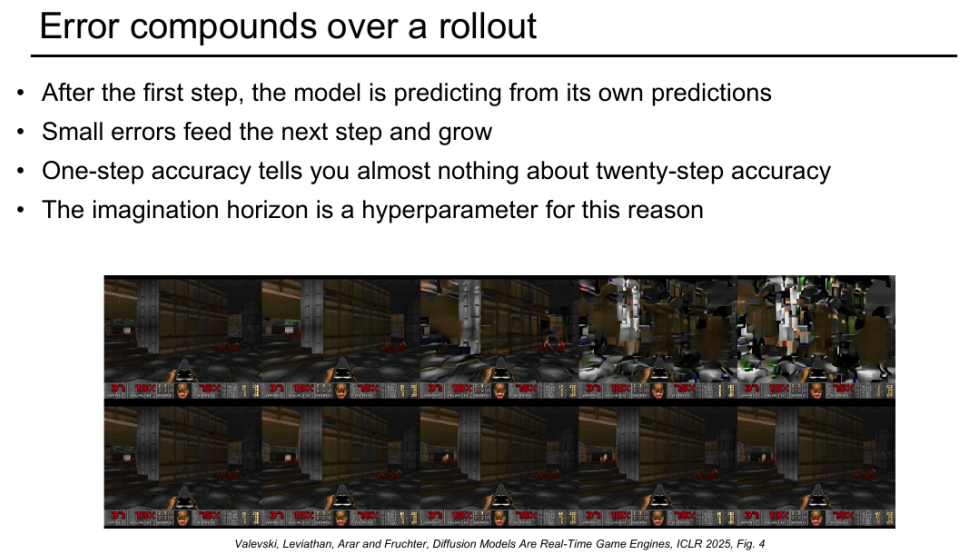

原课件第 14 页：智能体利用学得模型的缺陷

学得的模型可能以我们不知道的方式出错；在有缺陷的模型中进行优化的智能体会找到这些缺陷。Ha 和 Schmidhuber（2018）在智能体对 VizDoom 的梦境中训练智能体；它找到一种策略，使世界模型完全不再生成火球，在梦中获得满分，却在真实游戏中失败。图源：Ha and Schmidhuber, *World Models*, NeurIPS 2018, Fig. 18。

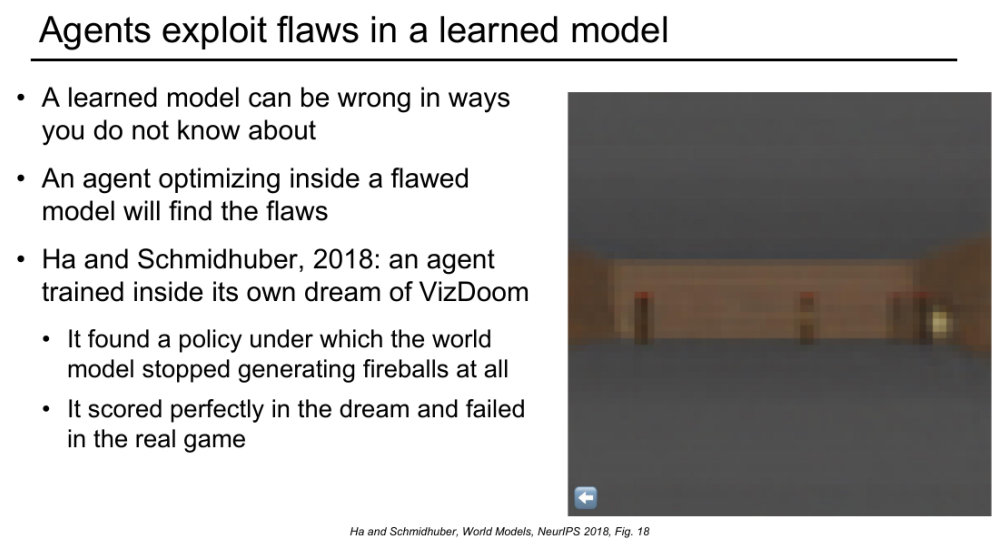

原课件第 15 页：F 是序列模型

F 将状态与动作映射到下一状态，这是经典的序列建模问题。Ha 和 Schmidhuber 使用 LSTM，Dreamer 使用 GRU，IRIS 和 STORM 使用 Transformer；因此需要了解一些循环模型。

原图比较两种结构。两图的 H 均为 RNN，输入为 $a_{t-1}, h_{t-1}, z_{t-1}$；左图 F 为 MDN，右图 F 为 SSM。两者均从 x_t 经编码器 E 得到 z_t，从 H 经 F 得到 $\hat{z}_t$，以两者形成损失；右图另有

h_t 指向编码器的连接，并将损失写为 $\mathcal{L}_{\text{pred}} + \mathcal{L}_{\text{dyn}} + \mathcal{L}_{\text{rep}}$。来源：arXiv:2606.12783, Fig. 5。

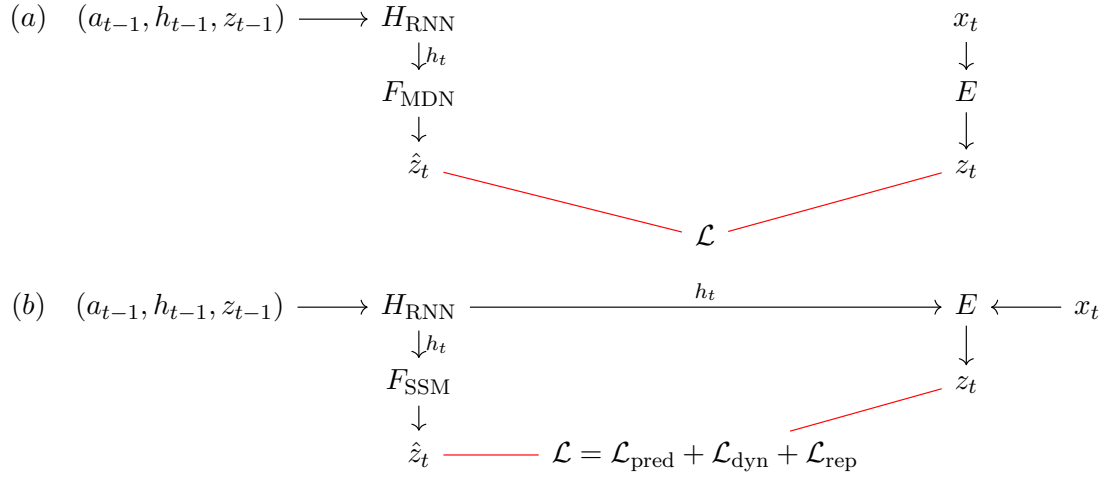

F is a sequence model

- F maps a state and an action to the next state
- Classic sequence modeling problem
- Ha and Schmidhuber: LSTM. Dreamer: GRU
- IRIS and STORM: a transformer
- This requires knowing a bit about recurrent models

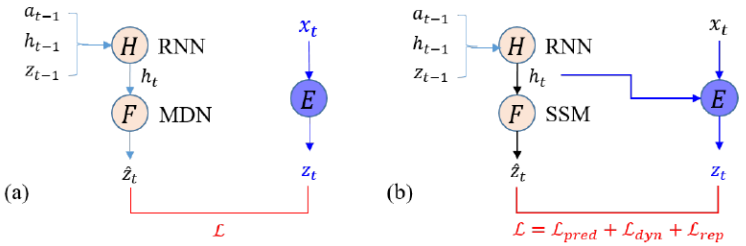

World Models

arXiv:2606.12783, Figure 5.

原课件第 16 页：提纲

前一部分是智能体内部的模型；接下来依次是循环模型（普通 RNN、LSTM、GRU）、瓶颈与注意力、Transformer（自注意力、位置编码、视觉 Transformer）、无标签学习、强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 17 页：循环网络

原图展示四种序列输入与输出的结构。课件注明许多幻灯片改编自 Arun Mallya、Justin Johnson 及 Stanford CS231n。单输入、多输出。

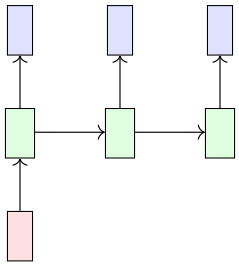

多输入、单输出。

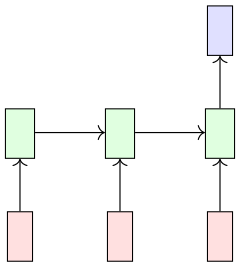

多输入、多输出（前后错开）。

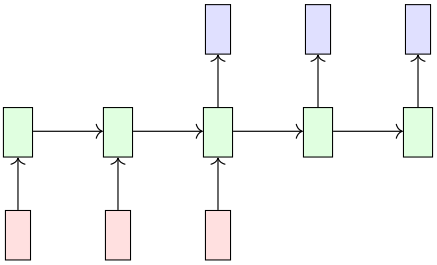

多输入、多输出（同步）。

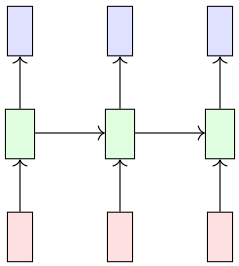

Recurrent networks

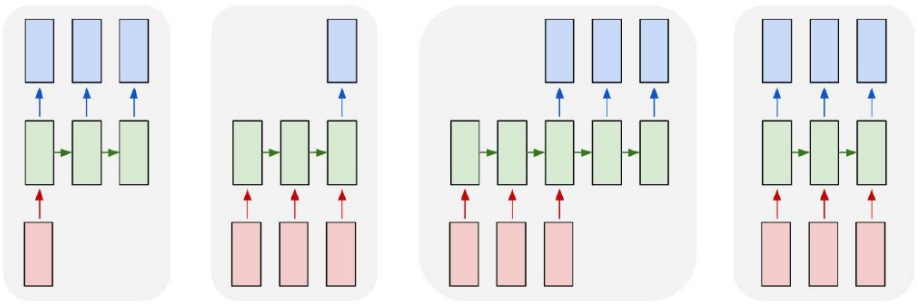

Many slides adapted from Arun Mallya and Justin Johnson (and Stanford CS231n)

Image source

原课件第 18 页：序列预测任务 1——文本分类

例如情感分类：将一个文本序列（如餐厅、电影或产品评论，或推文）分类为积极或消极情感。例句：“食物真的很好吃。”“吸尘器不到两周就坏了。”“电影有些部分节奏缓慢，但总体上值得一看。”

原课件第 19 页：序列预测任务 2——文本生成

从给定文本语料的分布中采样，也称语言建模。原页配有 RNN Bible 账户截图，介绍称使用字符级循环神经网络生成随机圣经式经句。可读示例包括：“万军之耶和华如此说：现在问这些石头是为义人和以色列的儿女的吗？”“他们从大卫城取了十二块石头，并击溃约旦。”“耶和华将向你的神耶和华送去一句箴言，却不会每次都笑。”“其中断裂的景象将成碎石，他们将把石头从地上拿走。”这些是生成文本的内容，不视为真实经文。

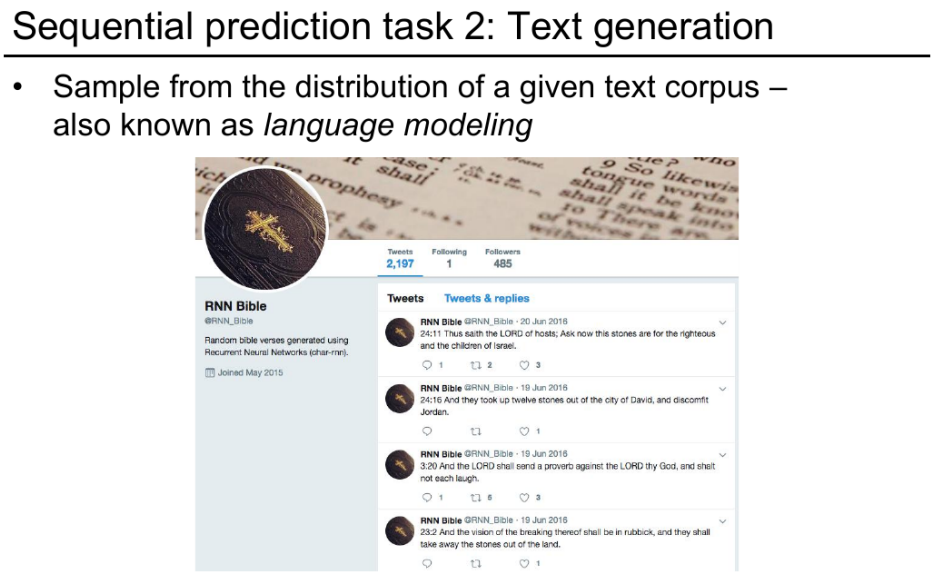

原课件第 20 页：序列预测任务 3——图像描述

八幅图片及其机器生成描述依次为：一只猫坐在地板上的手提箱上；一只猫坐在树枝上；一只狗叼着飞盘在草地上奔跑；一只白色泰迪熊坐在草地上；两个人拿着冲浪板在海滩上行走；一位网球运动员在场上比赛；两只长颈鹿站在草地上；一个人骑越野摩托车行驶在土路上。来源：J. Johnson；描述由 neuraltalk2 生成。

原课件第 21 页：序列预测任务 4——机器翻译

图示 Google Translate 中从法语到英语的翻译示例；原页链接为 https://translate.google.com/。截图以 Charles Baudelaire 的法语诗《Correspondances》及机器给出的英语译文为例。所示英文大意：自然是一座活的柱子有时发出含混话语的神殿；人穿过象征的森林，它们以熟悉目光注视他。远处融成幽暗深邃统一体的长回声，广阔如黑夜与光明；香气、色彩和声音相互呼应。有些香气如儿童肌肤般清新，甜如双簧管、绿如草地；另一些腐败、丰饶而辉煌，具有无限事物的扩展，如琥珀、麝香、安息香与乳香，歌唱精神与感官的狂喜。截图原文和机器译文并列保留，文字对读尚需独立审校。

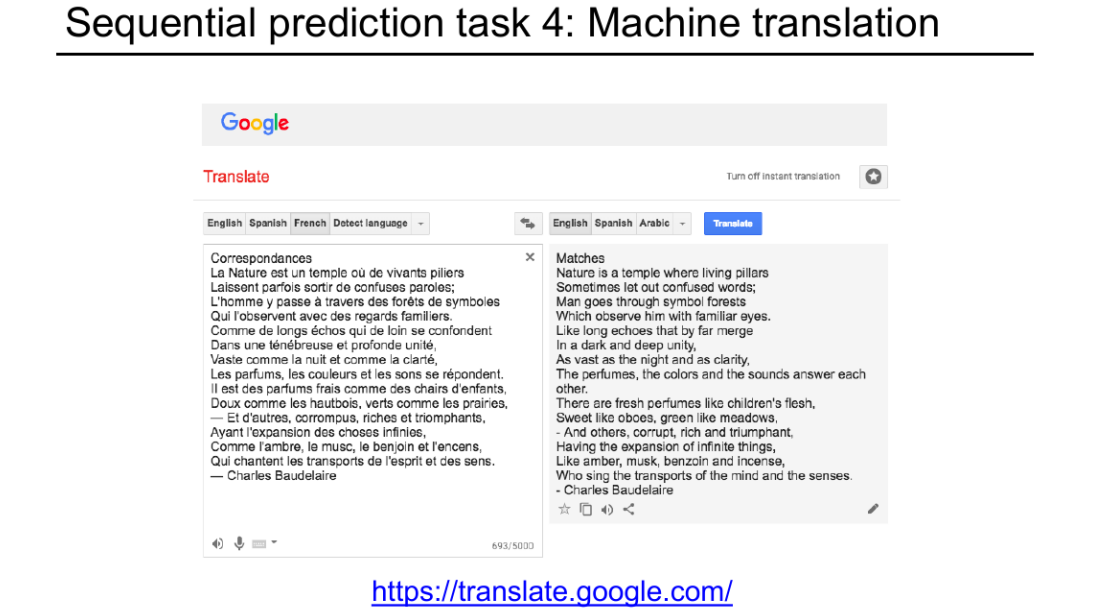

原课件第 22 页：输入输出情形总结

- 单输入、单输出：前馈网络。
- 多输入、单输出：序列分类。
- 单输入、多输出：序列生成、图像描述。
- 多输入、多输出：序列生成、图像描述。
- 多输入、多输出：翻译。

原图用箭头分别展示同步或前后错开的输入、输出与网络节点。单输入、单输出：前馈网络。

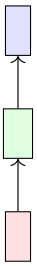

多输入、单输出：序列分类。

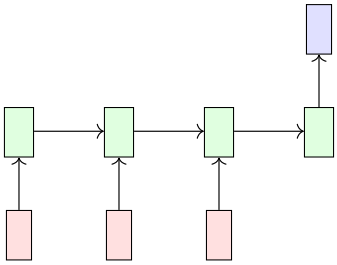

单输入、多输出：序列生成、图像描述。

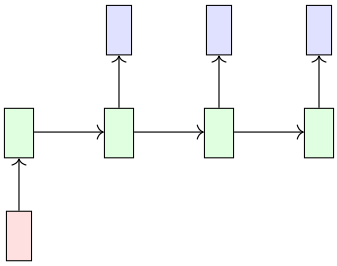

多输入、多输出：序列生成、图像描述。

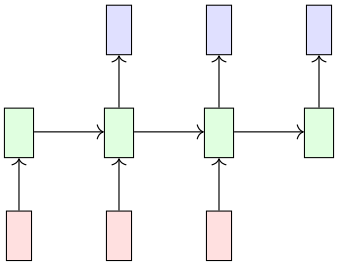

多输入、多输出：翻译。

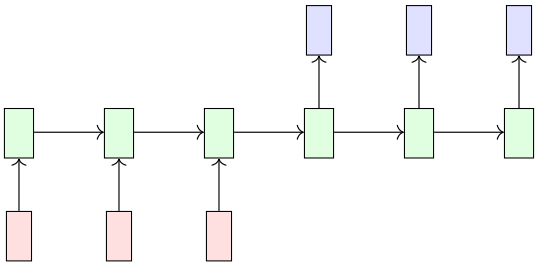

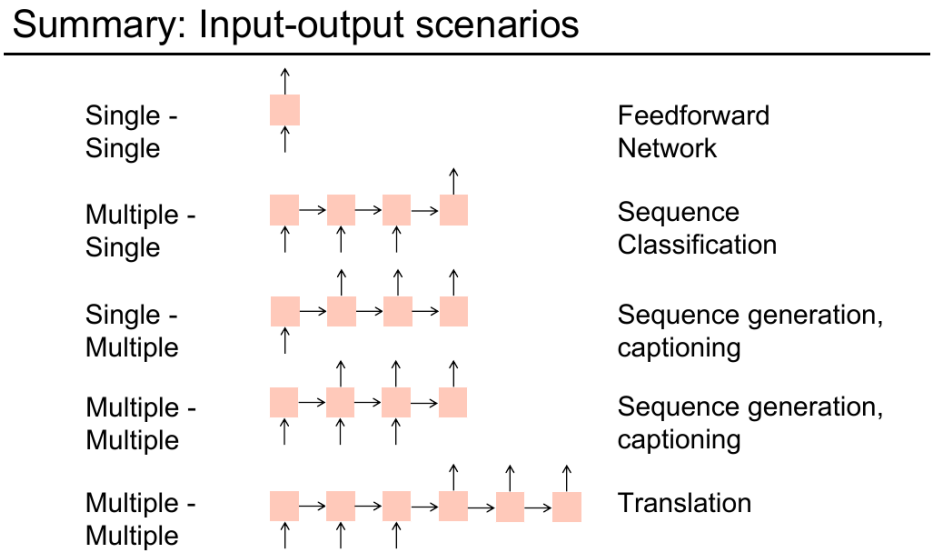

原课件第 23 页：循环单元

原图沿时间 $t = 1, 2, 3$ 展开：输入 x_t 进入隐层，隐状态 h_t 传至下一时刻并进入分类器，产生输出 y_t；初始状态为 h_0。

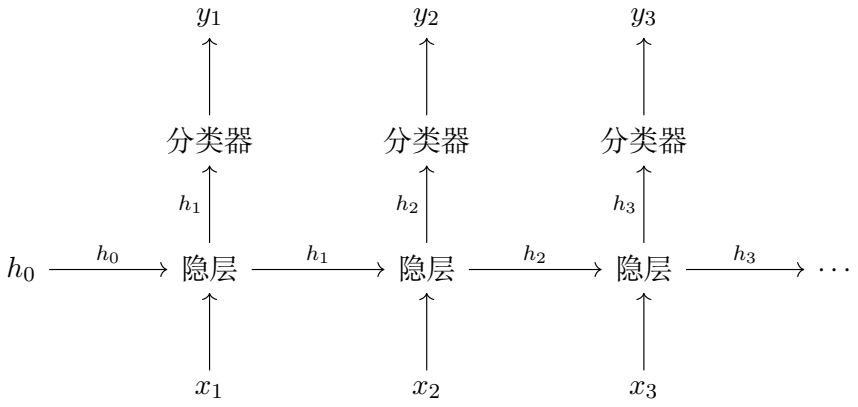

三列依次对应 $t = 1, 2, 3$。

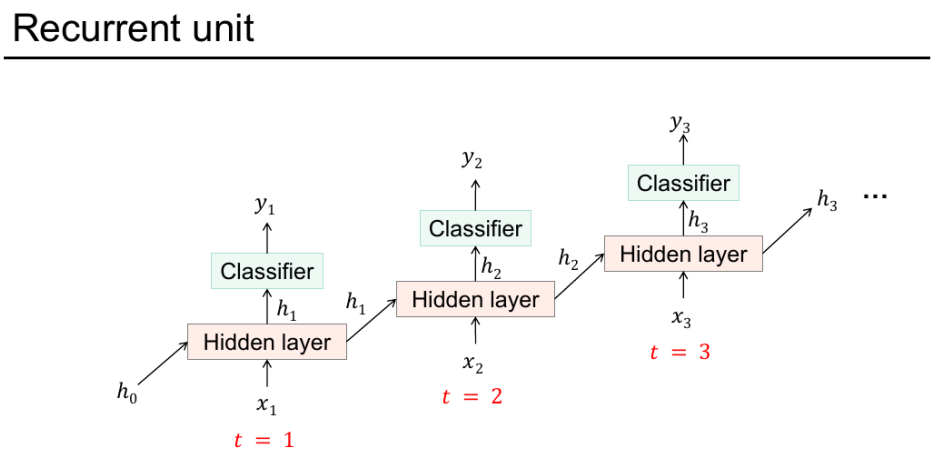

原课件第 24 页：循环单元（续）

时刻 t 的输入为 x_t，隐表示为 h_t，输出为 y_t。递推关系是

$$h_t = f_W(x_t, h_{t-1}),$$

其中 h_t 是新状态，f_W 是由 W 参数化的函数，x_t 是当前输入，h_{t-1} 是旧状态。

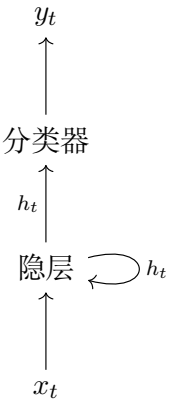

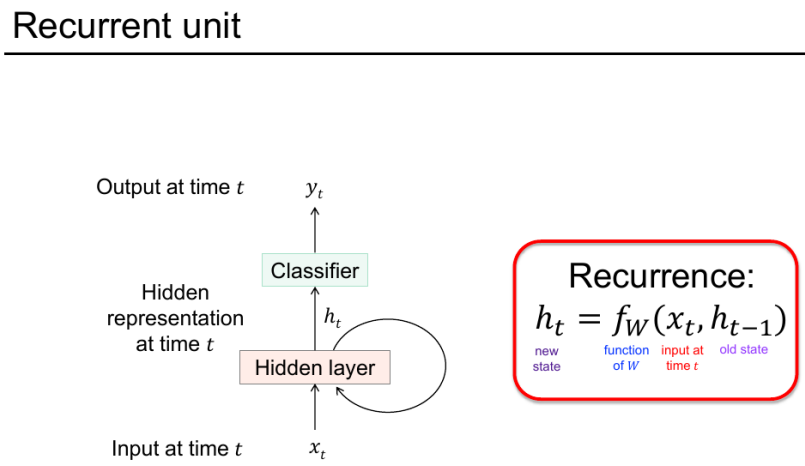

原课件第 25 页：普通 RNN 单元

$$h_t = f_W(x_t, h_{t-1}) = \tanh\left(W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}\right).$$

来源：J. Elman, *Finding structure in time*, Cognitive Science 14(2), pp. 179–211, 1990。

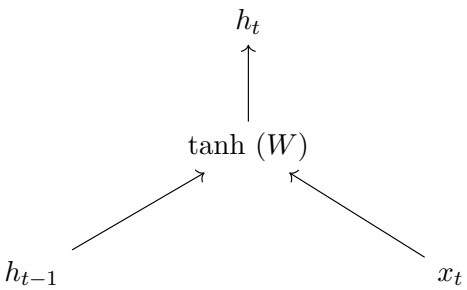

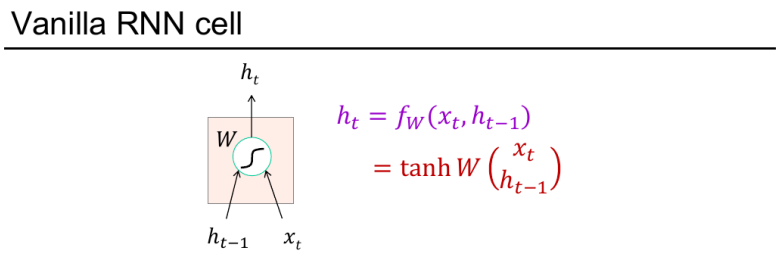

J. Elman, Finding structure in time, Cognitive science 14(2), pp. 179–211, 1990

原课件第 26 页：普通 RNN 单元与双曲正切

沿用上一页递推式。图中比较 $\sigma(a)$ 与 $\tanh(a)$，并给出

$$\tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}} = 2\sigma(2a) - 1.$$

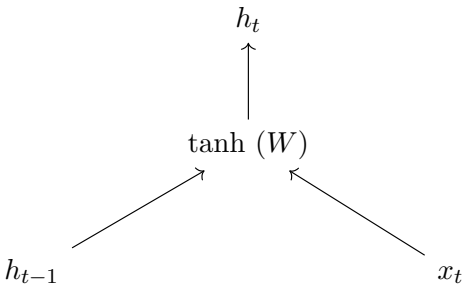

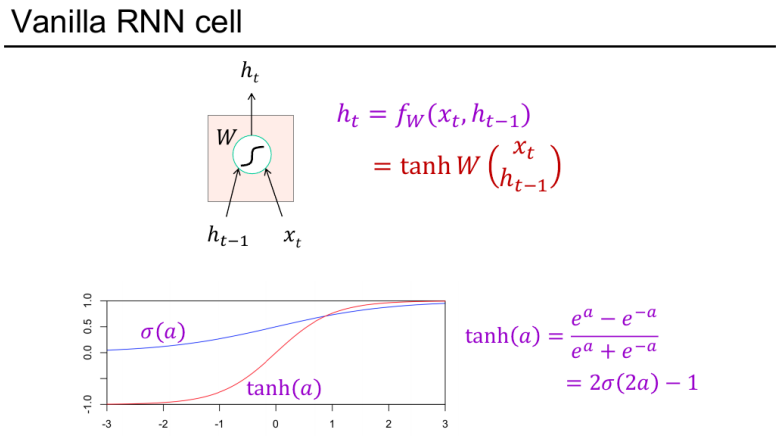

原课件第 27 页：双曲正切的导数

沿用第 25 页的 RNN 递推式，图中比较双曲正切及其导数：

$$\frac{d}{da}\tanh(a) = 1 - \tanh^2(a).$$

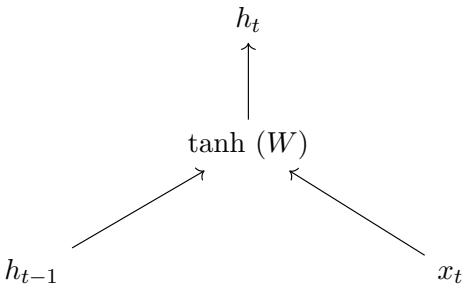

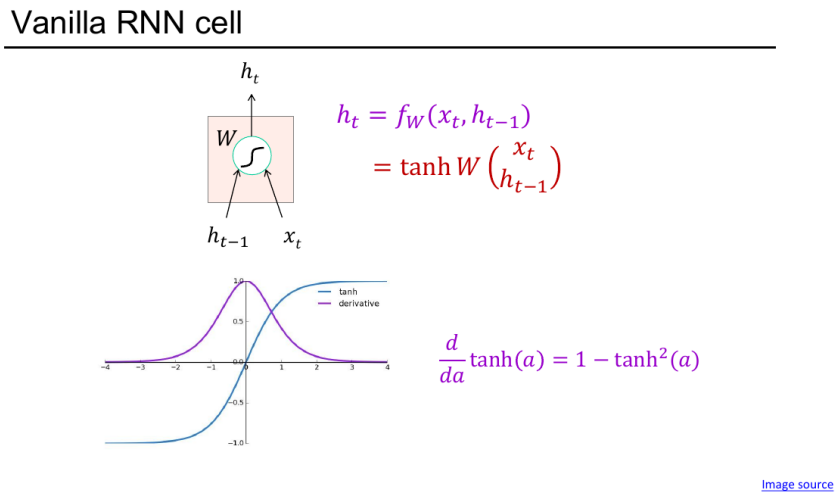

原课件第 28 页：分块权重

将 W 分成 W_x 和 W_h，得到

$$h_t = f_W(x_t, h_{t-1}) = \tanh\left(W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}\right) = \tanh(W_x x_t + W_h h_{t-1}).$$

图中 x_t 为 n 维、h_{t-1} 为 m 维；权重块 W_x 和 W_h 的行数为 m，列数分别为 n 和 m。

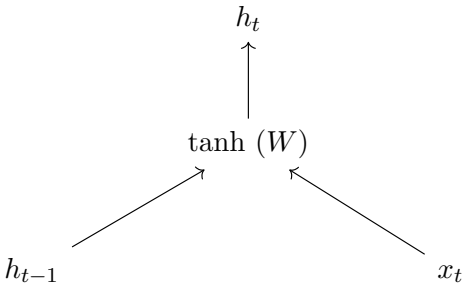

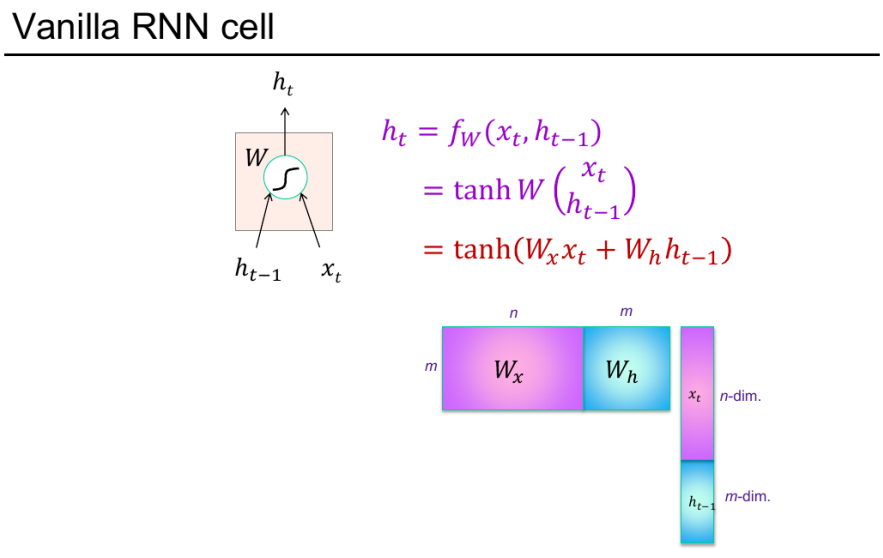

原课件第 29 页：RNN 前向传播

原图沿时间展开，虚线表示共享权重；GT_t 是图中的真实标签记号。原式为

$$e_t = -\log\big(y_t(GT_t)\big), \qquad y_t = \mathrm{softmax}(W_y h_t),$$

$$h_t = \tanh\left(W\begin{pmatrix} x_t \\ h_{t-1}\end{pmatrix}\right).$$

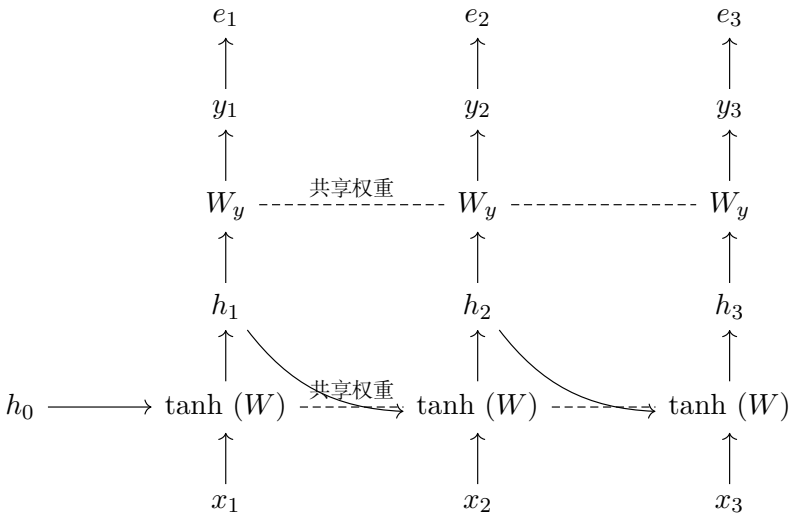

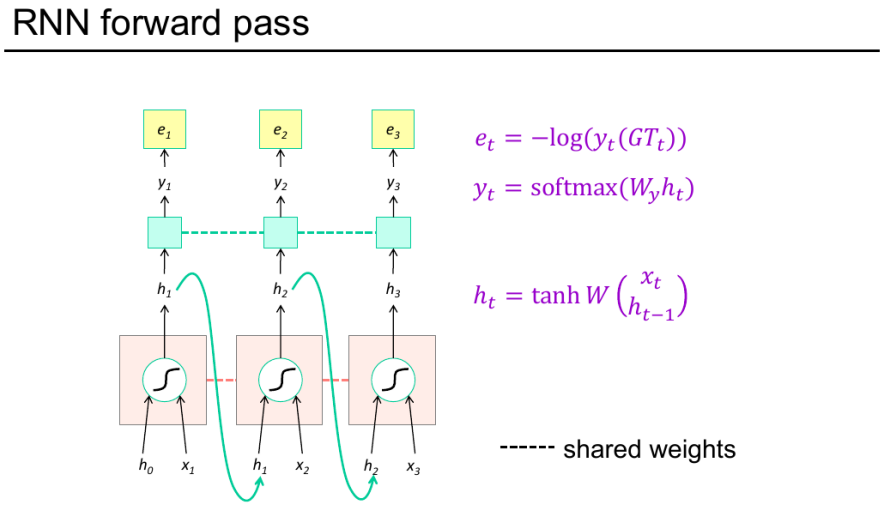

原课件第 30 页：RNN 前向传播的计算图

原图重复上一页公式，并将共享参数 W_y, W 以及各步误差指向总损失 L 的计算关系显式画出。

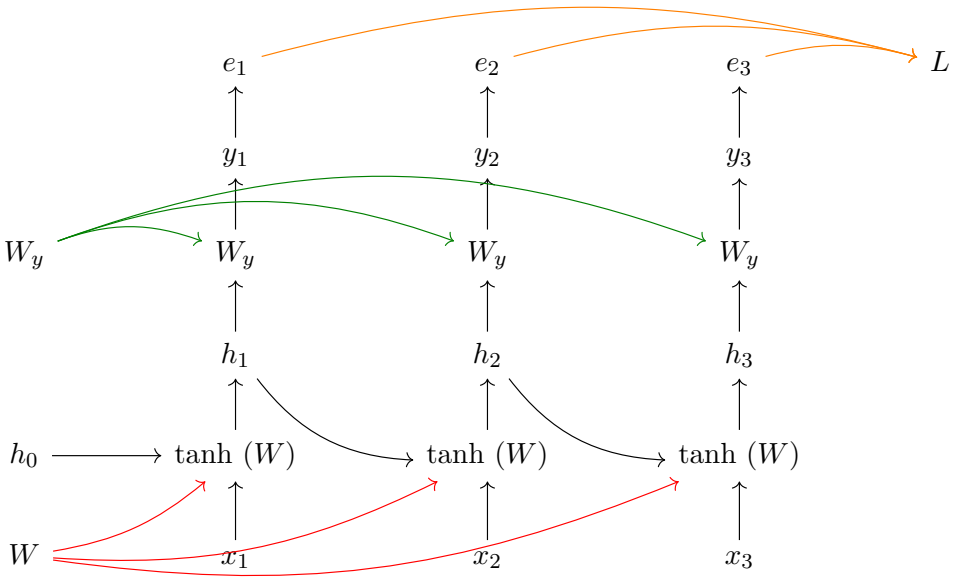

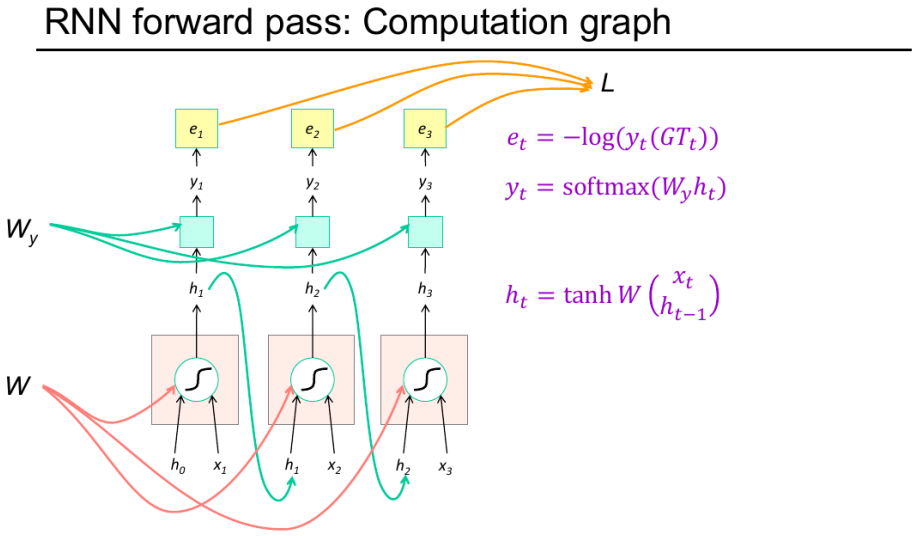

原课件第 31 页：梯度消失与爆炸

原页给出

$$\frac{\partial e}{\partial h_{t-1}} = W_h^T \left(1 - \tanh^2(W_x x_t + W_h h_{t-1})\right) \odot \frac{\partial e}{\partial h_t}.$$

课件称，计算 h_0 的梯度涉及多次乘以 W_h^T 和介于 0 与 1 之间的缩放；又称 W_h 的最大奇异值小于 1 时梯度消失，大于 1 时梯度爆炸。后一断言保留原文表述，其充分条件与逐元素乘法的括号位置需进一步核查，不能仅由最大奇异值大于 1 推断必然爆炸。

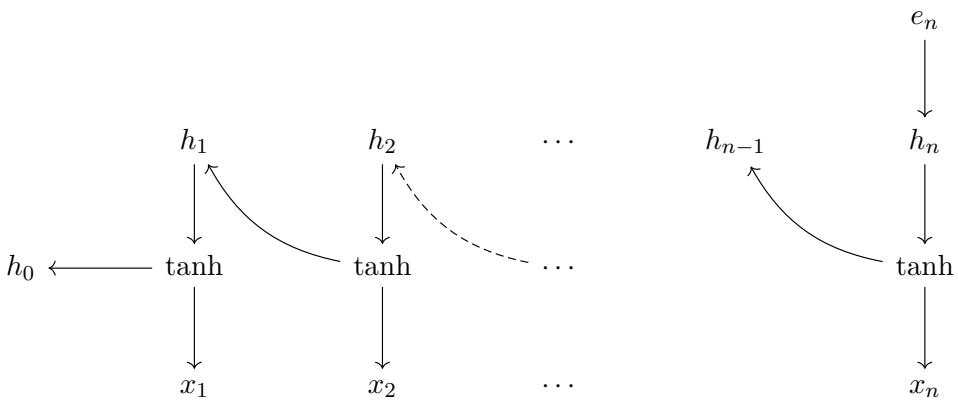

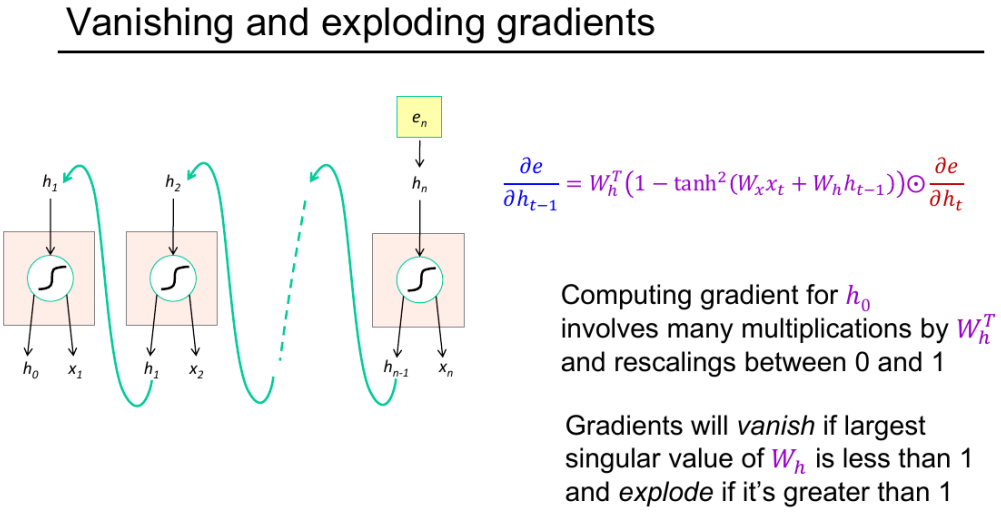

原课件第 32 页：长短期记忆（LSTM）

增加一个不经过矩阵乘法或挤压变换的记忆单元，从而避免梯度衰减（依原课件表述）。图示输入 x_t, h_{t-1}, c_{t-1} 和输出 h_t, c_t。来源：S. Hochreiter and J. Schmidhuber, *Long short-term memory*, Neural Computation 9(8), pp. 1735–1780, 1997。**译注：**这是对记忆路径的动机说明，并非任意 LSTM 都不发生梯度衰减的保证；门控后的直接单元状态路径含遗忘门的乘积，仍可能衰减。

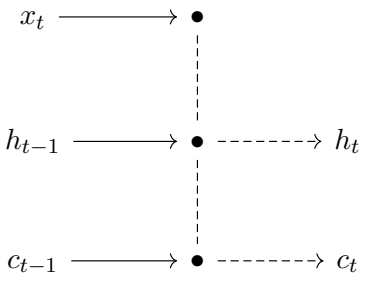

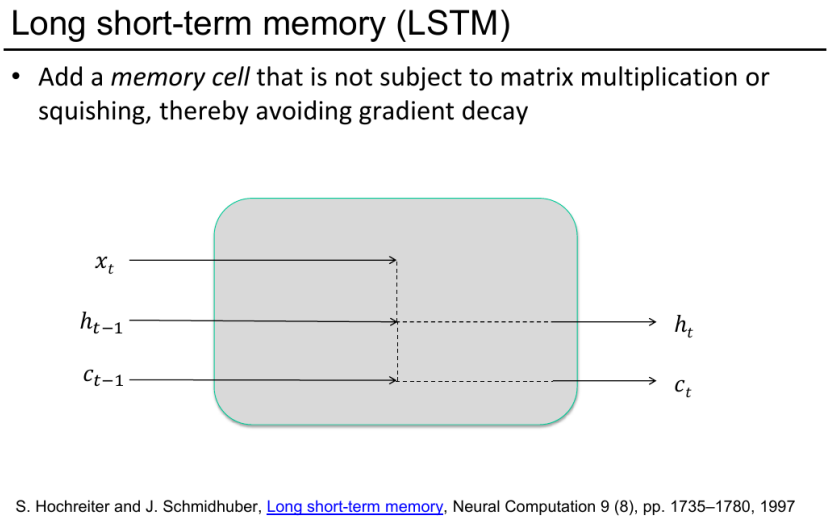

原课件第 33 页：LSTM 单元

原图首先引入候选量：

$$g_t = \tanh\left(W_g \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}\right).$$

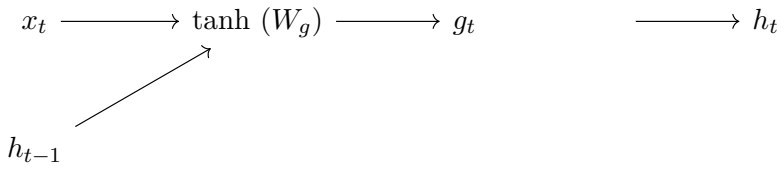

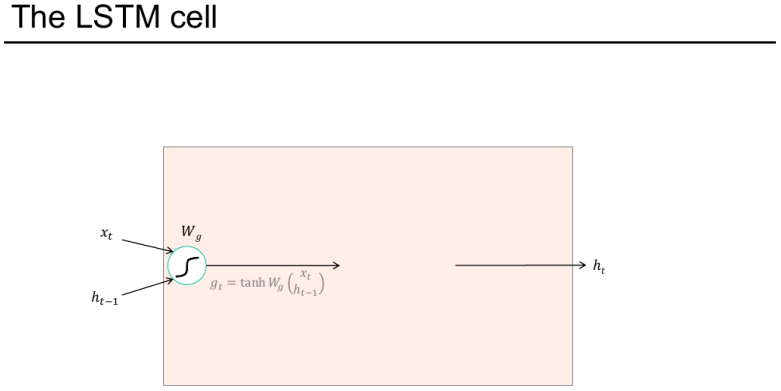

原课件第 34 页：引入单元状态

该页的中间结构写作 $c_t = c_{t-1} + g_t$，$h_t = \tanh c_t$。这是课件逐步构造中的中间式，后续引入门控。

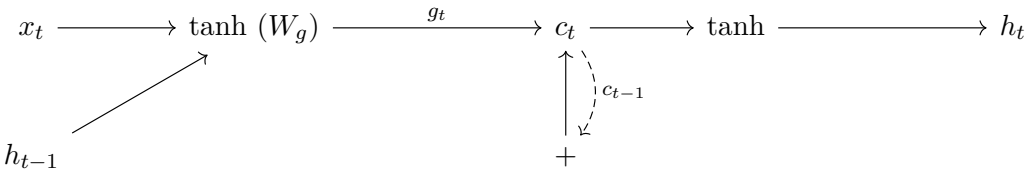

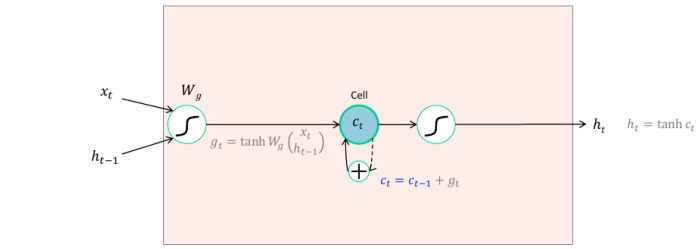

原课件第 35 页：LSTM 单元（续）

图中保留候选量 g_t、单元状态和输出路径，为引入门控作准备。

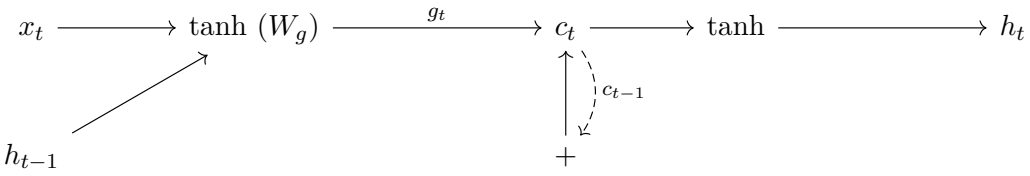

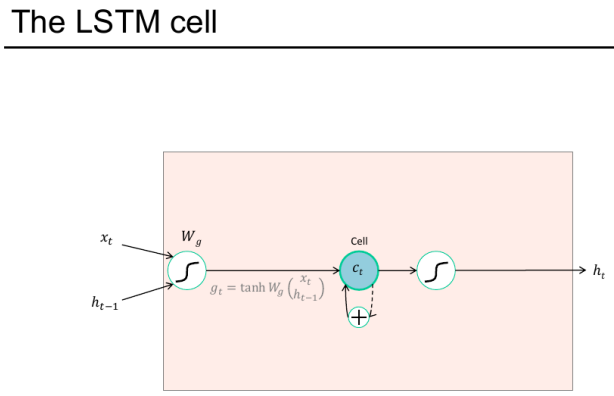

原课件第 36 页：输入门

$$i_t = \sigma\left(W_i \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_i\right), \qquad c_t = c_{t-1} + i_t \odot g_t.$$

图中的 g_t 仍为第 33 页所给的候选量。

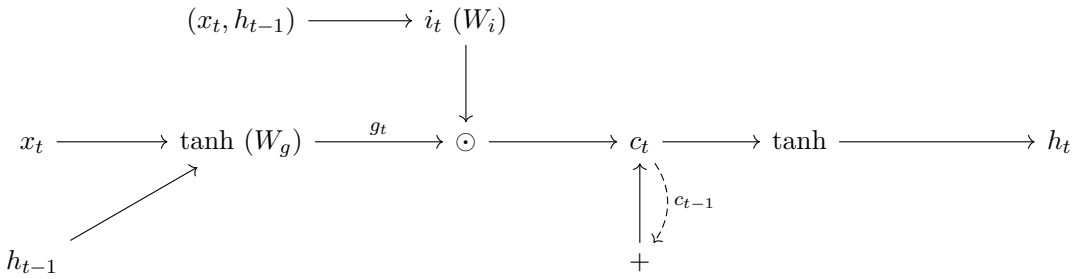

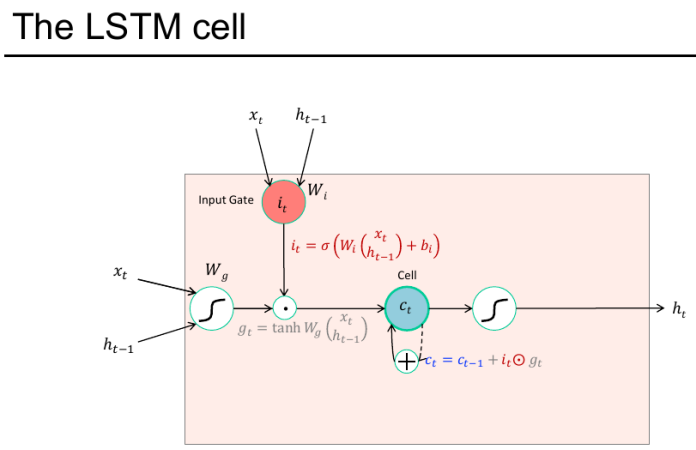

原课件第 37 页：输出门

$$o_t = \sigma\left(W_o \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_o\right), \qquad h_t = o_t \odot \tanh c_t.$$

本页保留输入门、候选量与前页单元状态更新式。

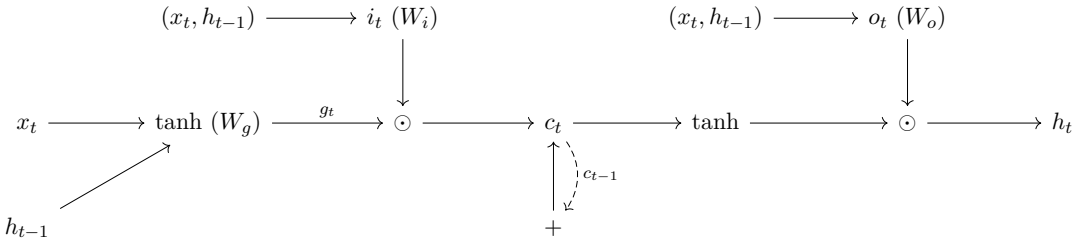

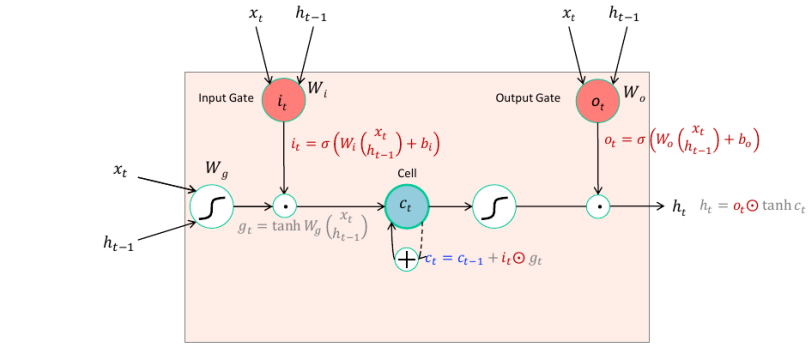

原课件第 38 页：遗忘门

$$f_t = \sigma\left(W_f \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_f\right), \qquad c_t = f_t \odot c_{t-1} + i_t \odot g_t.$$

图中同时保留 i_t, o_t, g_t, h_t 的前述公式。

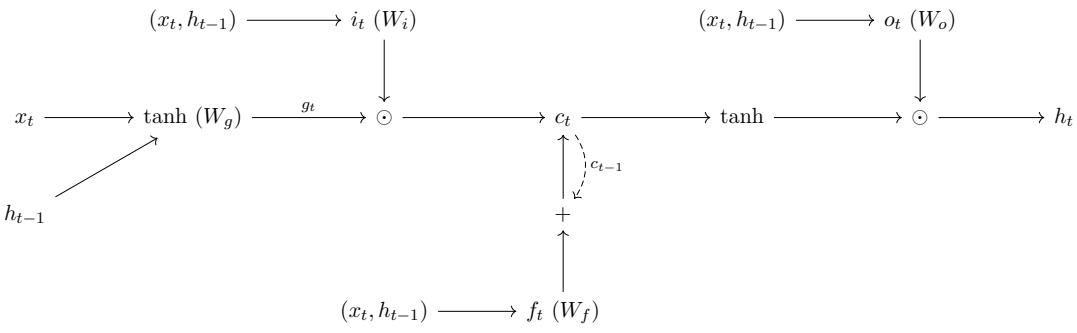

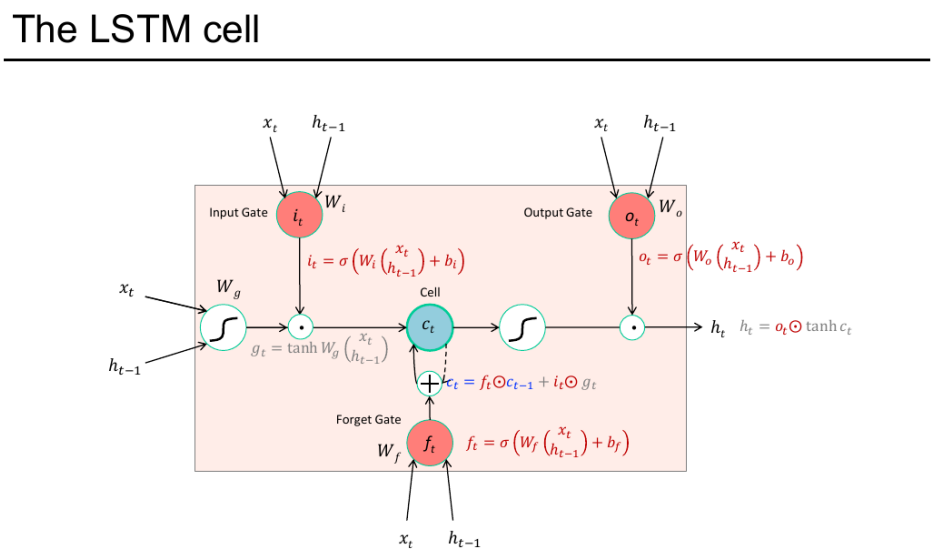

原课件第 39 页：LSTM 前向传播总结

原页将四个计算堆叠为

$$\begin{pmatrix} g_t \\ i_t \\ f_t \\ o_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \\ \sigma \end{pmatrix} \begin{pmatrix} W_g \\ W_i \\ W_f \\ W_o \end{pmatrix} \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix},$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \qquad h_t = o_t \odot \tanh c_t.$$

该汇总图未显示前几页门控式中的偏置项；这里照原样保留。

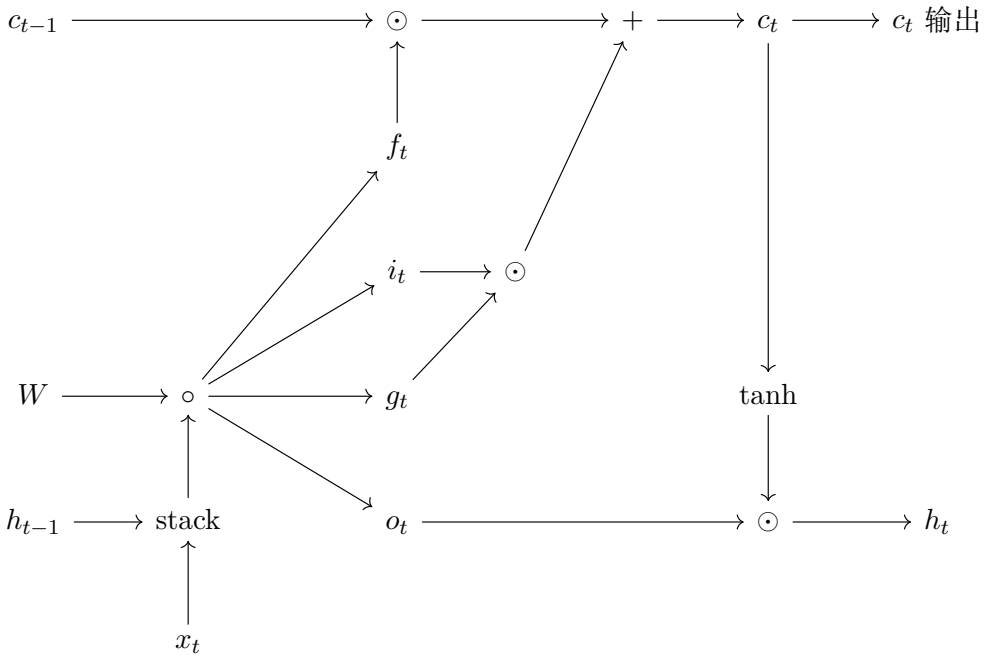

LSTM forward pass summary

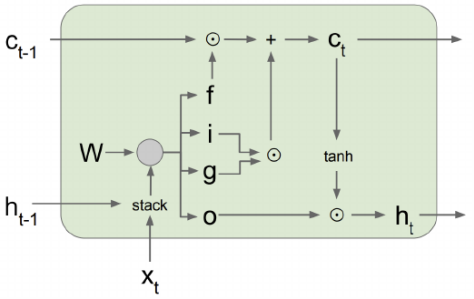

$$\begin{pmatrix} g_t \\ i_t \\ f_t \\ o_t \end{pmatrix} = \begin{pmatrix} \tanh \\ \sigma \\ \sigma \\ \sigma \end{pmatrix} \begin{pmatrix} W_g \\ W_i \\ W_f \\ W_o \end{pmatrix} \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

$$h_t = o_t \odot \tanh c_t$$

Figure source

原课件第 40 页：门控循环单元（GRU）

原页从普通递推单元开始：

$$h_t = \tanh\left(W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}\right).$$

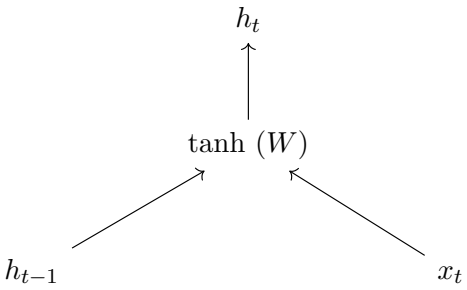

Gated recurrent unit (GRU)

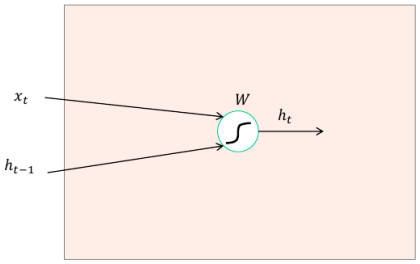

$$h_t = \tanh W \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix}$$

原课件第 41 页：LSTM 变体——GRU

去掉单独的单元状态，并将“遗忘”和“输出”门合并为“更新”门。原页写作

$$
\begin{aligned}
r_t &= \sigma\left(W_r \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_t\right), \\
h'_t &= \tanh\left(W \begin{pmatrix} x_t \\ r_t \odot h_{t-1} \end{pmatrix}\right), \\
z_t &= \sigma\left(W_z \begin{pmatrix} x_t \\ h_{t-1} \end{pmatrix} + b_z\right), \\
h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot h'_t.
\end{aligned}
$$

其中 r_t 为重置门、z_t 为更新门。偏置下标 b_t 依原页保留，是否为笔误有待核对。来源：K. Cho et al., *Learning phrase representations using RNN encoder-decoder for statistical machine translation*, ACL 2014。

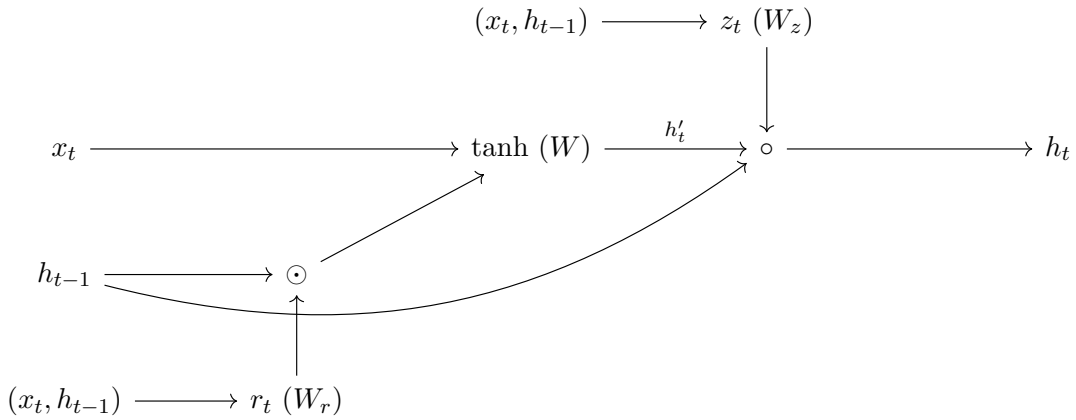

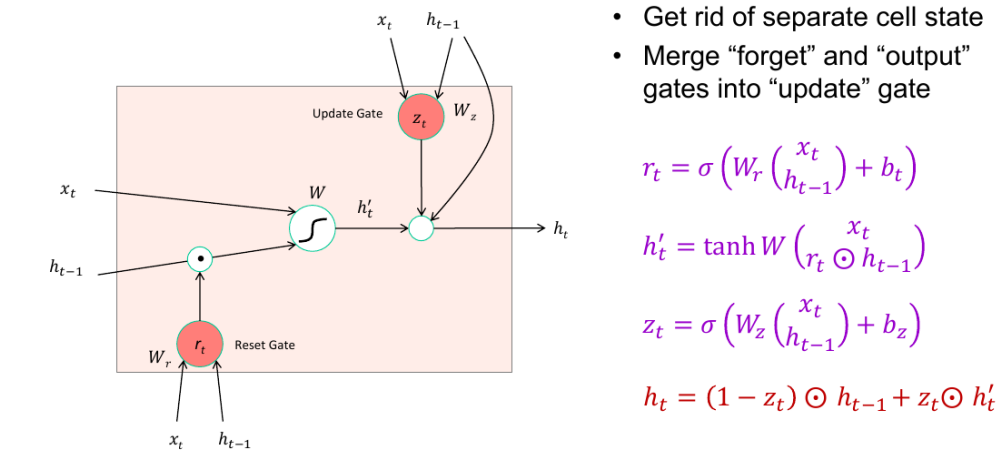

K. Cho et al., Learning phrase representations using RNN encoder-decoder for statistical machine translation, ACL 2014

原课件第 42 页：RNN 架构

原图给出最一般的配置：按时间排列的输入 $x_1, \ldots, x_6$ 经循环网络得到输出 $y_1, \ldots, y_6$。

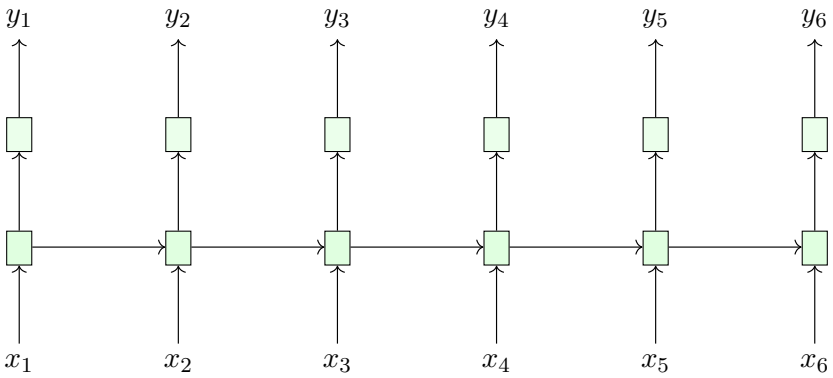

RNN architectures

- Most general configuration:

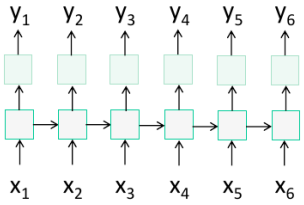

原课件第 43 页：多层 RNN

可以设计具有多个隐层的 RNN；也可以采用跨层、跨时间等跳跃连接。原图示意六个时刻的多层网络。

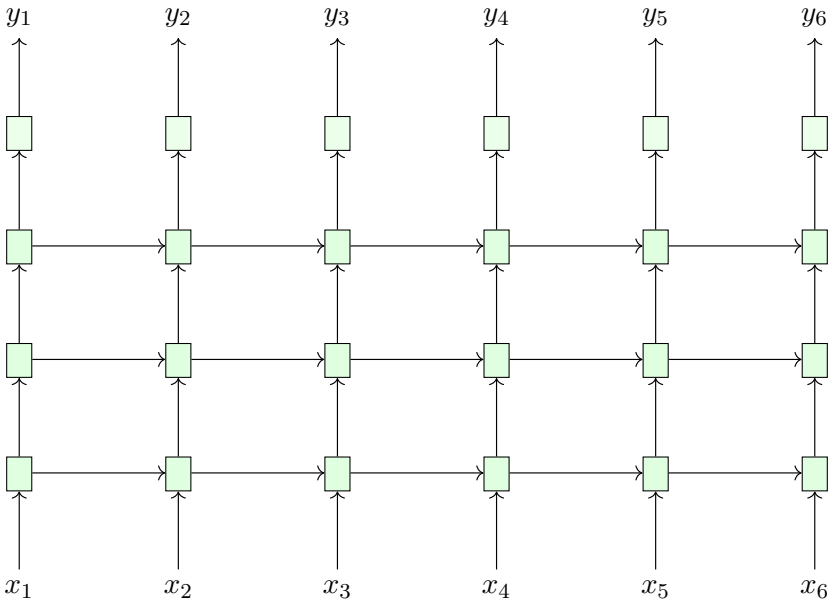

Multi-layer RNNs

- We can of course design RNNs with multiple hidden layers

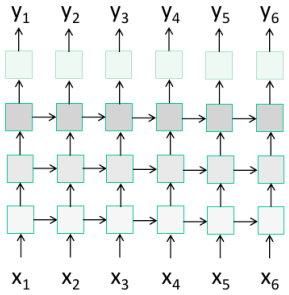

- Anything goes: skip connections across layers, across time, …

原课件第 44 页：双向 RNN

RNN 可以沿正向和反向处理输入序列，这在语音识别中很常见。

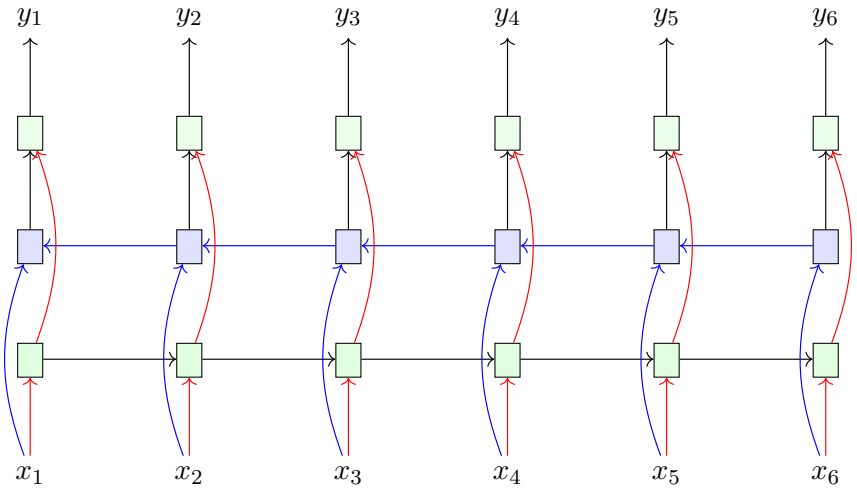

Bi-directional RNNs

- RNNs can process the input sequence in forward and in the reverse direction (common in speech recognition)

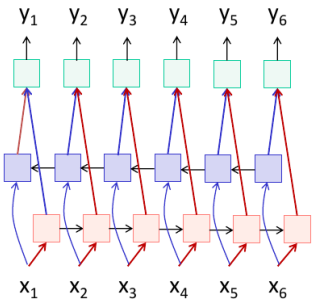

原课件第 45 页：循环部分在世界模型中的位置

GRU 将确定性状态向前传递；随机潜变量吸收它无法预测的部分；两者合称 RSSM。图示 RNN、SSM 与 RSSM 的状态及观测连接。来源：arXiv:2606.12783, Fig. 7。RNN。

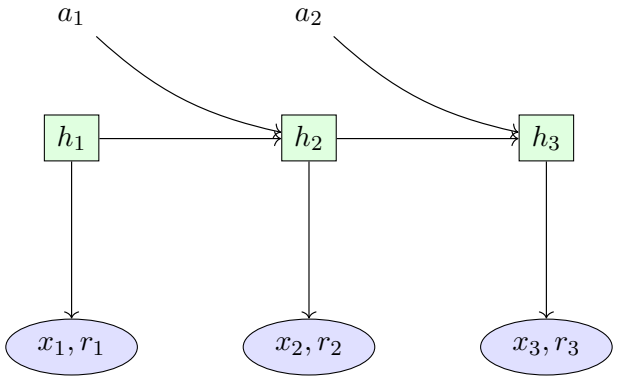

SSM。

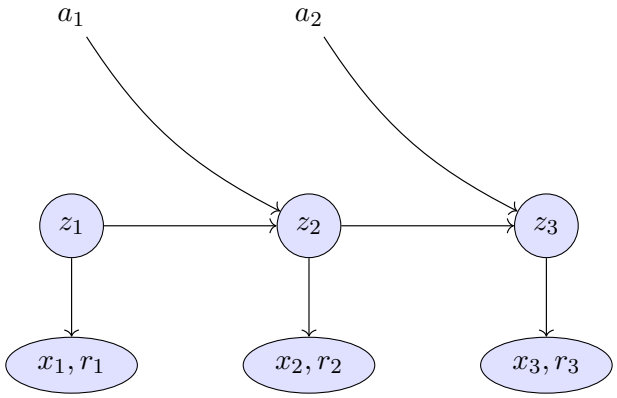

RSSM。

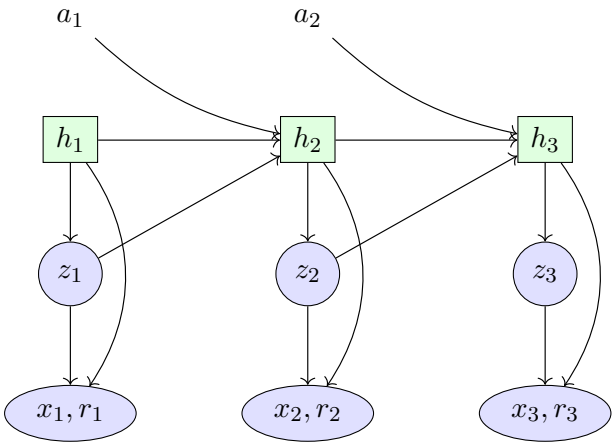

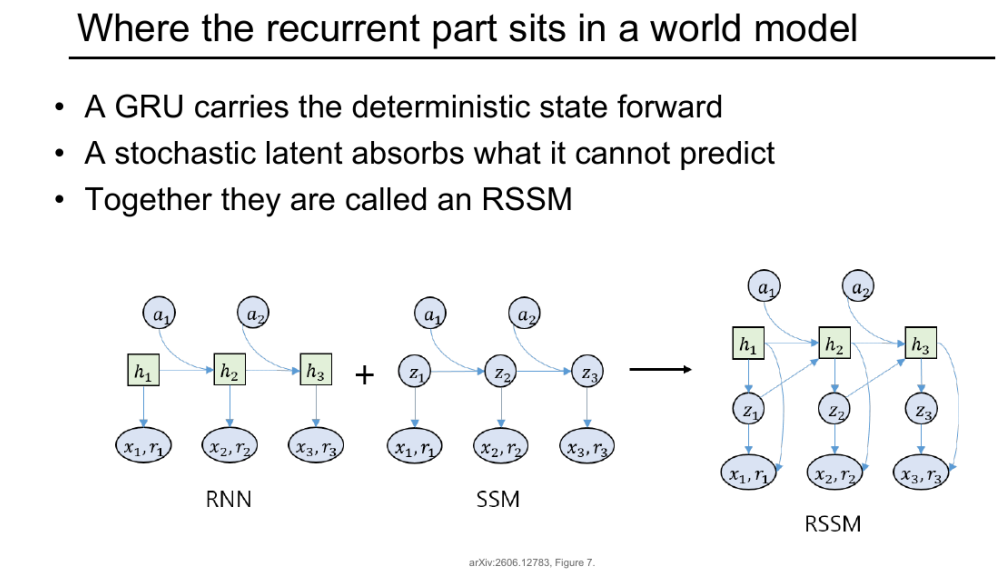

原课件第 46 页：提纲

继智能体内部模型和循环模型后，接下来讨论瓶颈与注意力、Transformer（自注意力、位置编码、视觉 Transformer）、无标签学习、强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 47 页：带注意力的序列到序列模型

原图展示翻译中的注意力矩阵以及图像描述词语与图像区域的关联；图中文字 “a bird flying over a body of water” 意为 “一只鸟飞过一片水域”。矩阵横轴为英文 “The agreement on the European Economic Area was signed in August 1992 . <end>”，纵轴为法文 “L’ accord sur la zone économique européenne a été signé en août 1992 . <end>”；该矩阵和标注的进一步说明见本份第 59 页。许多幻灯片改编自 J. Johnson。

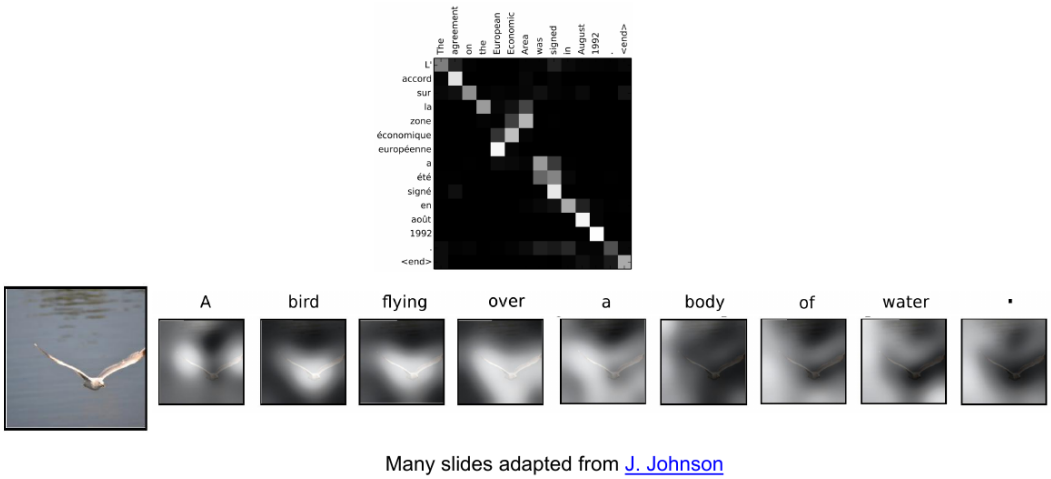

原课件第 48 页：序列到序列建模——机器翻译

例句：英语“我们正在吃面包”（We are eating bread）译为西班牙语“Estamos comiendo pan”。

$$\text{We are eating bread} \longrightarrow \text{Estamos comiendo pan}$$

原课件第 49 页：使用 RNN 的序列到序列建模

原页展示两种编码器–解码器结构。来源：I. Sutskever, O. Vinyals, Q. Le, *Sequence to Sequence Learning with Neural Networks*, NeurIPS 2014；K. Cho, B. Merrienboer, C. Gulcehre, F. Bougares, H. Schwenk and Y. Bengio, *Learning phrase representations using RNN encoder-decoder for statistical machine translation*, ACL 2014。

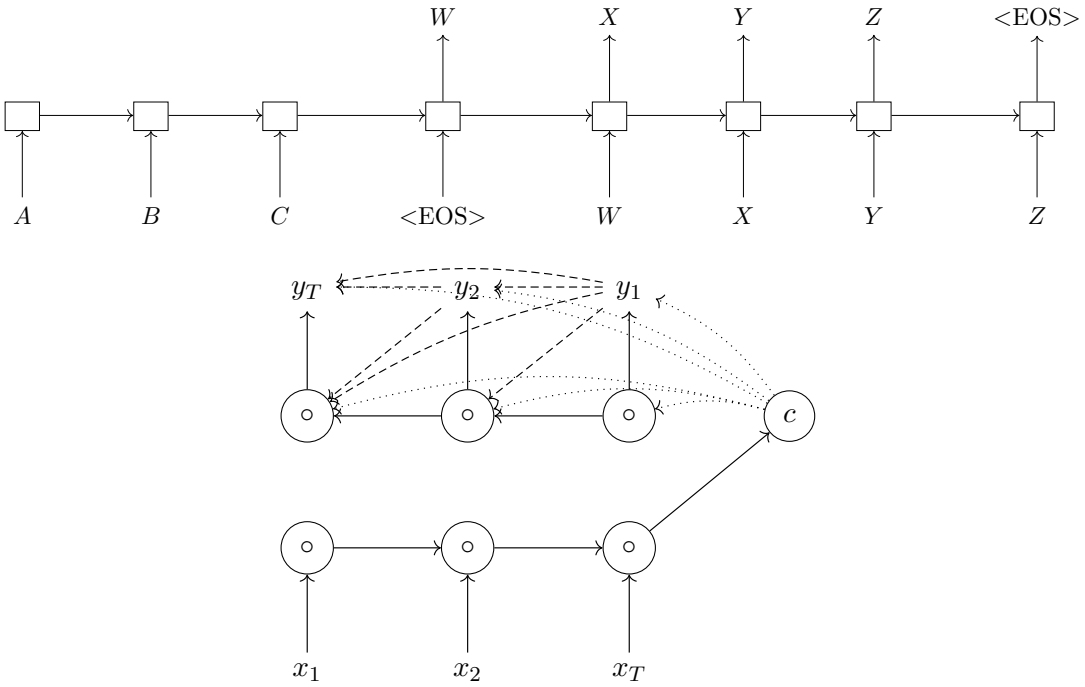

Sequence-to-sequence modeling with RNNs

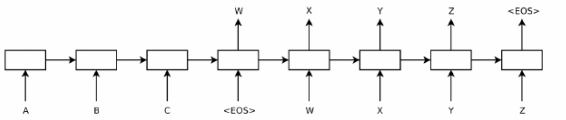

I. Sutskever, O. Vinyals, Q. Le, Sequence to Sequence Learning with Neural Networks, NeurIPS 2014

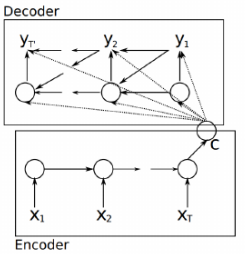

K. Cho, B. Merrienboer, C. Gulcehre, F. Bougares, H. Schwenk, and Y. Bengio, Learning phrase representations using RNN encoder-decoder for statistical machine translation, ACL 2014

原课件第 50 页：编码器与上下文向量

编码器递推式为 $h_t = f_W(x_t, h_{t-1})$。从最终隐状态预测解码器初始状态 s_0 和上下文向量 c（常取 $c = h_T$）。图中给出的做法是引入单独的上下文向量，以“记住”输入序列 *we are eating bread*。

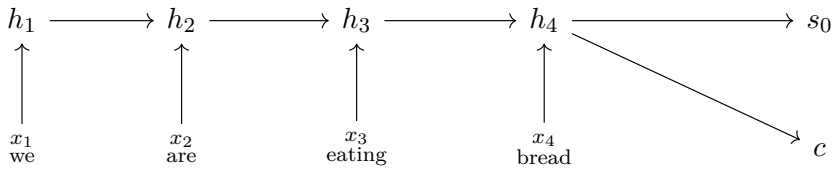

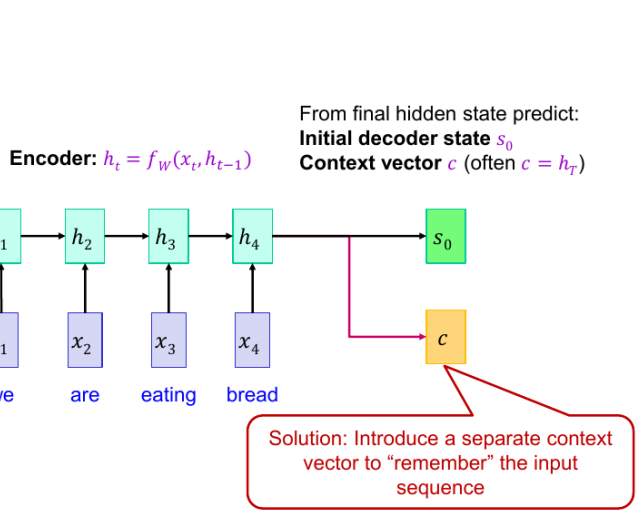

原课件第 51 页：固定向量瓶颈

解码器为 $s_t = g_U(y_{t-1}, s_{t-1}, c)$，从起始标记生成 *estamos comiendo pan* 和停止标记。问题是输入序列必须经过固定大小向量这一瓶颈；一个想法是在解码器每一步使用新的上下文向量。

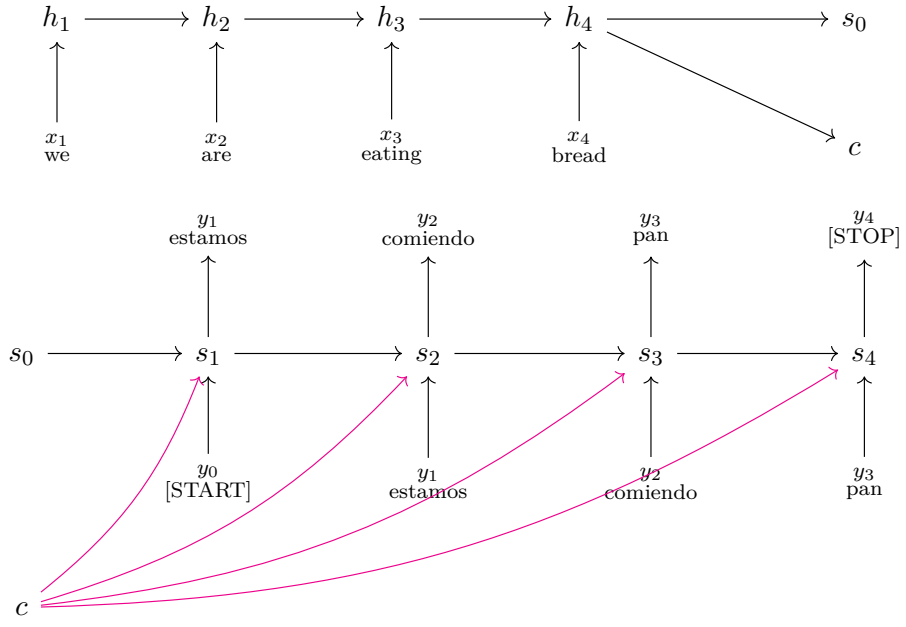

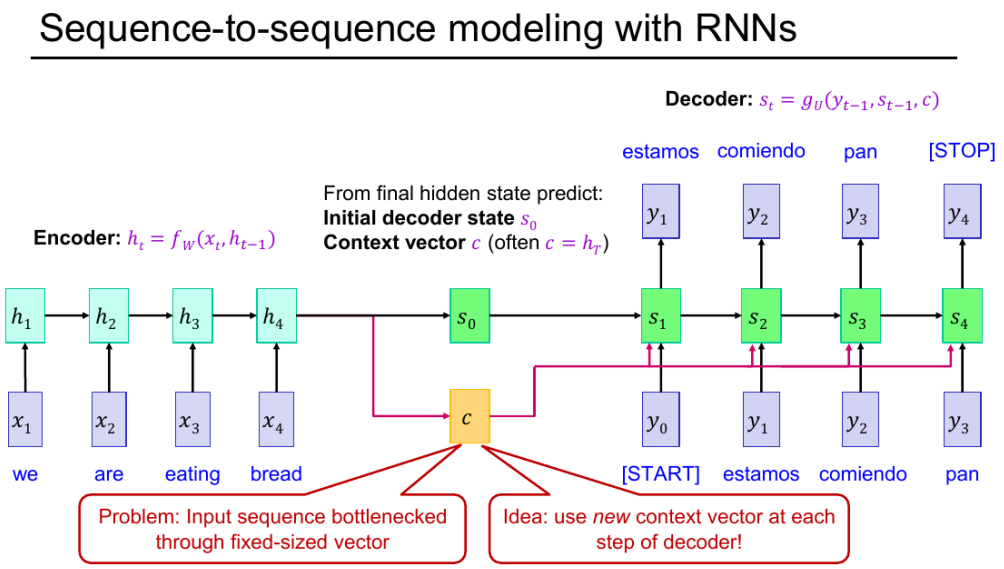

原课件第 52 页：带注意力的序列到序列模型

直观理解：翻译需要对齐。原图用连线对齐英语 “What is the anticipated cost of collecting fees under the new proposal?” 与法语 “En vertu de les nouvelles propositions, quel est le coût prévu de perception de les droits?”；句意为 “依照新提案，收取费用的预计成本是多少？” 图中连线对应 what/quel、is/est、the/le、anticipated/prévu、cost/coût、of/de、collecting/perception、fees/droits、under/en vertu de、the/les、new/nouvelles、proposal/propositions 及问号。法语形式按图保留。

以下可编辑连线按原页逐条保留；法语独立的逗号及末段未连线的 de、les 也照列：

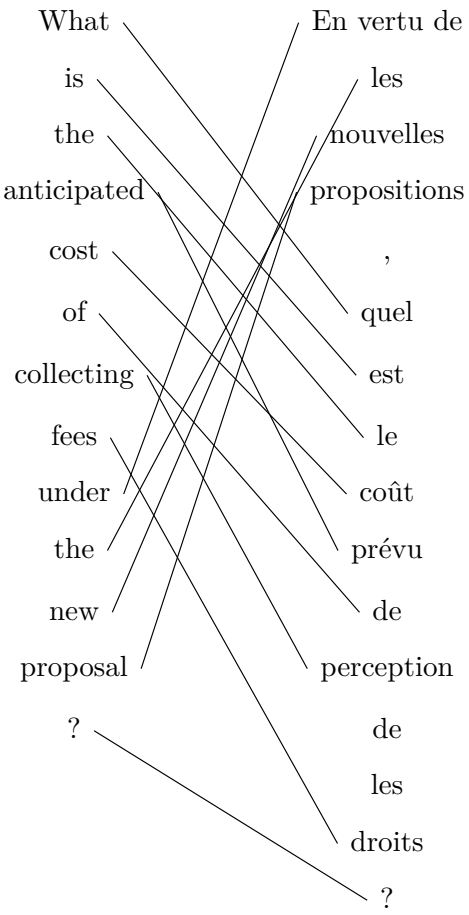

Sequence-to-sequence with RNNs *and attention*

- Intuition: translation requires *alignment*

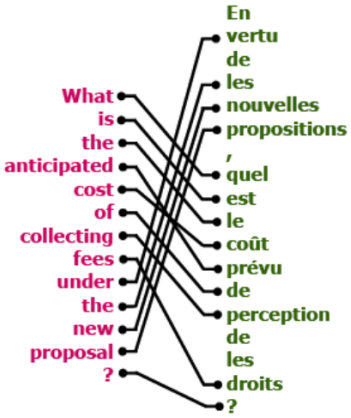

原课件第 53 页：逐步关注输入

解码器的每个时间步，上下文向量“观察”输入序列的不同部分；原图以 *we are eating bread* 为例。

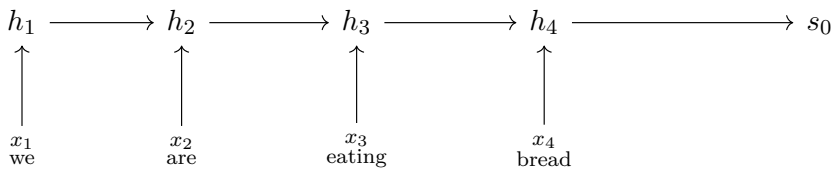

Sequence-to-sequence with RNNs and attention

- At each timestep of decoder, context vector “looks at” different parts of the input sequence

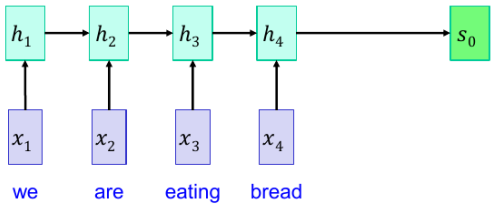

原课件第 54 页：注意力计算

计算标量对齐分数 $e_{t,i} = f_{\text{att}}(s_{t-1}, h_i)$，经 softmax 归一化为注意力权重 $a_{t,i}$，再计算上下文向量并用于解码器：

$$c_t = \sum_i a_{t,i} h_i, \qquad s_t = g_U(y_{t-1}, s_{t-1}, c_t).$$

直观上，上下文向量关注输入序列中相关的部分；例如 *estamos* 对应 *we are*，权重可能为 $a_{11} = a_{12} = 0.45$、$a_{13} = a_{14} = 0.05$。来源：D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate*, ICLR 2015。

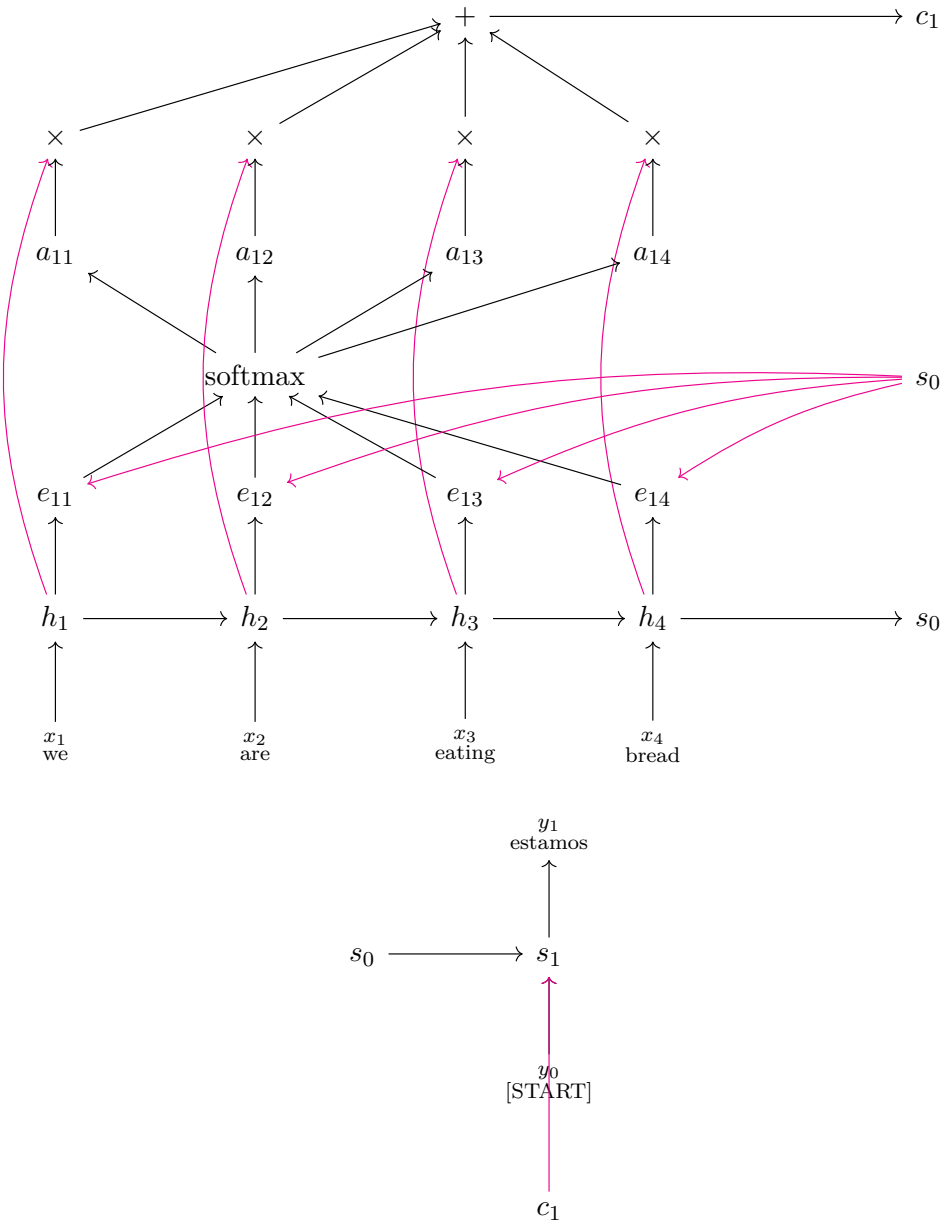

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

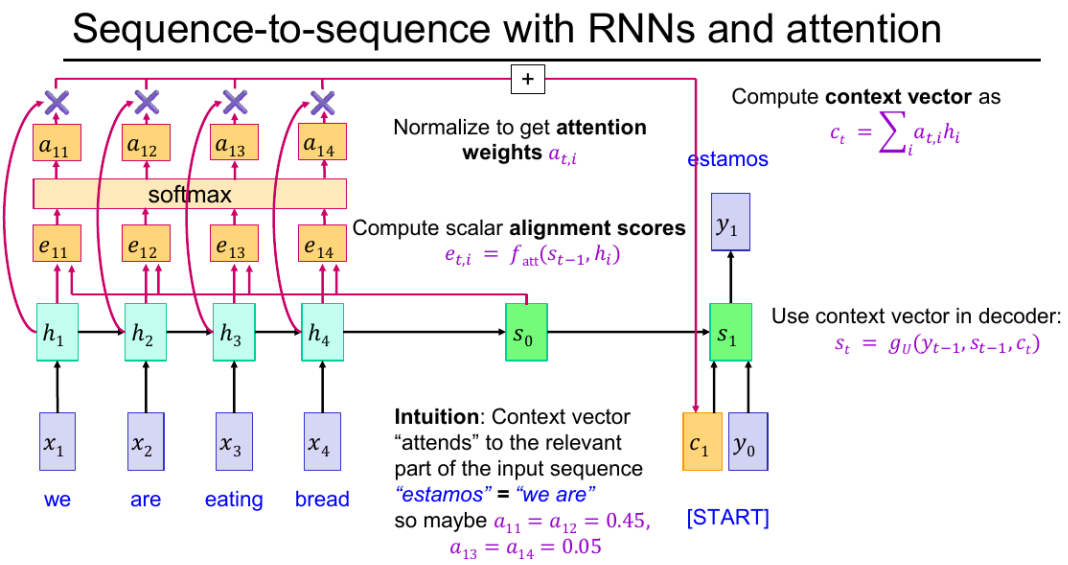

D. Bahdanau, K. Cho, Y. Bengio, Neural Machine Translation by Jointly Learning to Align and Translate, ICLR 2015

原课件第 55 页：注意力解码的第二步

重复前述过程：使用 s_1 计算新的上下文向量 c_2，再用 c_2 计算 s_2, y_2。图中对齐分数 e_{2i} 经 softmax 得到权重 a_{2i}，输出 *estamos comiendo*。

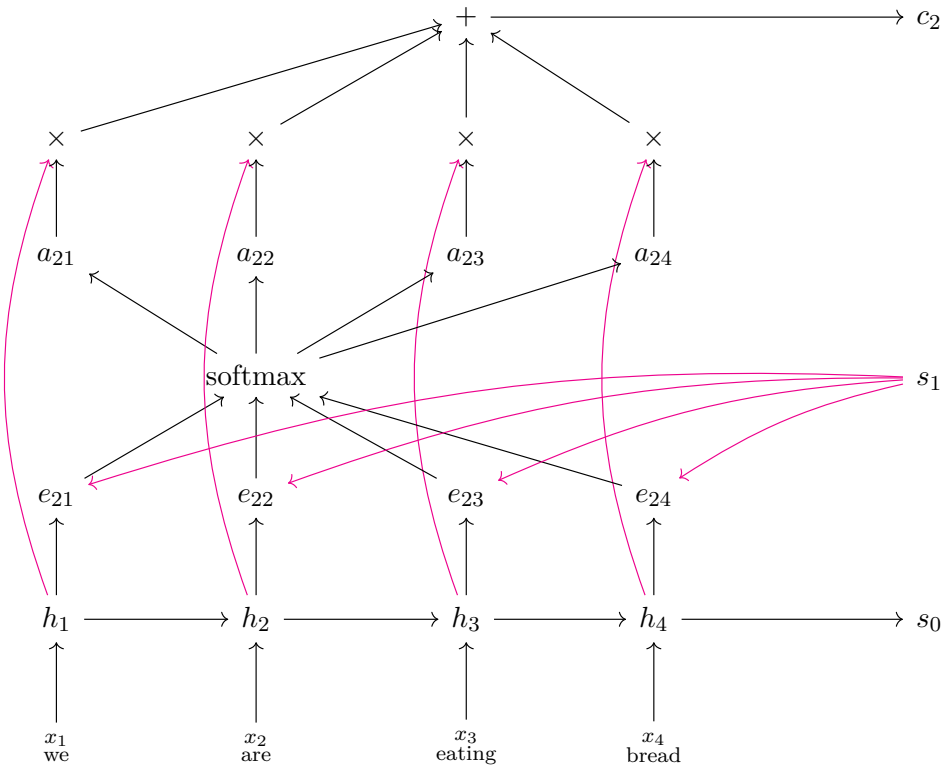

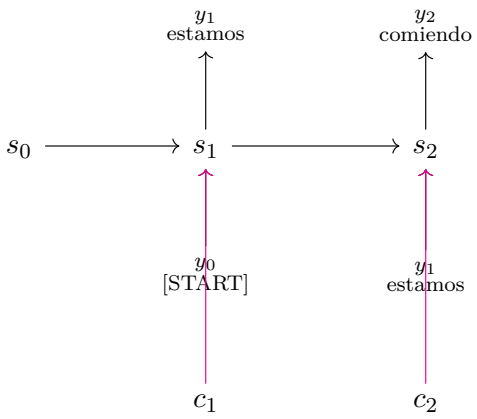

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

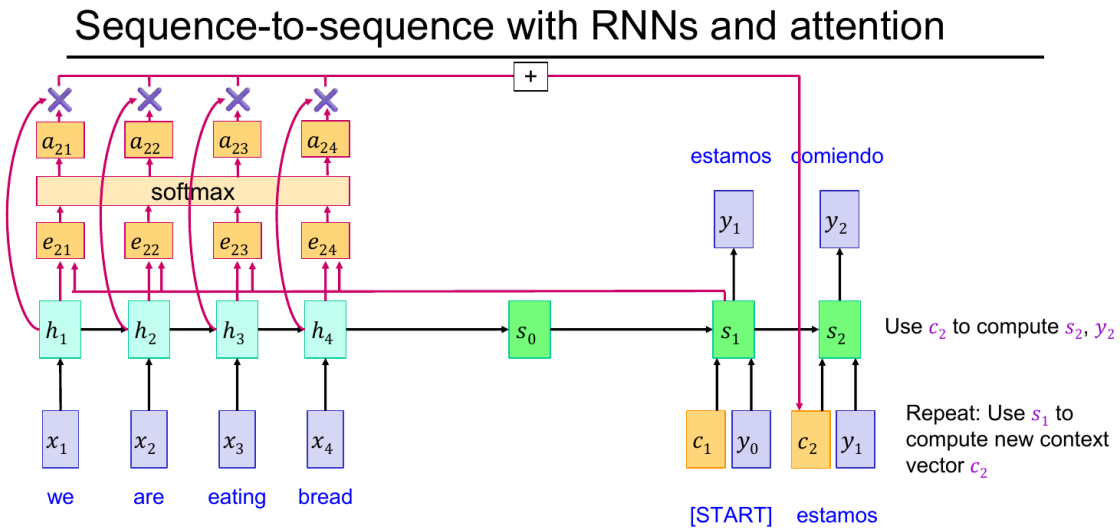

原课件第 56 页：注意力解码的第三步

图示权重 a_{3i}、分数 e_{3i}、上下文 c_3、状态 s_3 与输出 $y_3 = pan$。

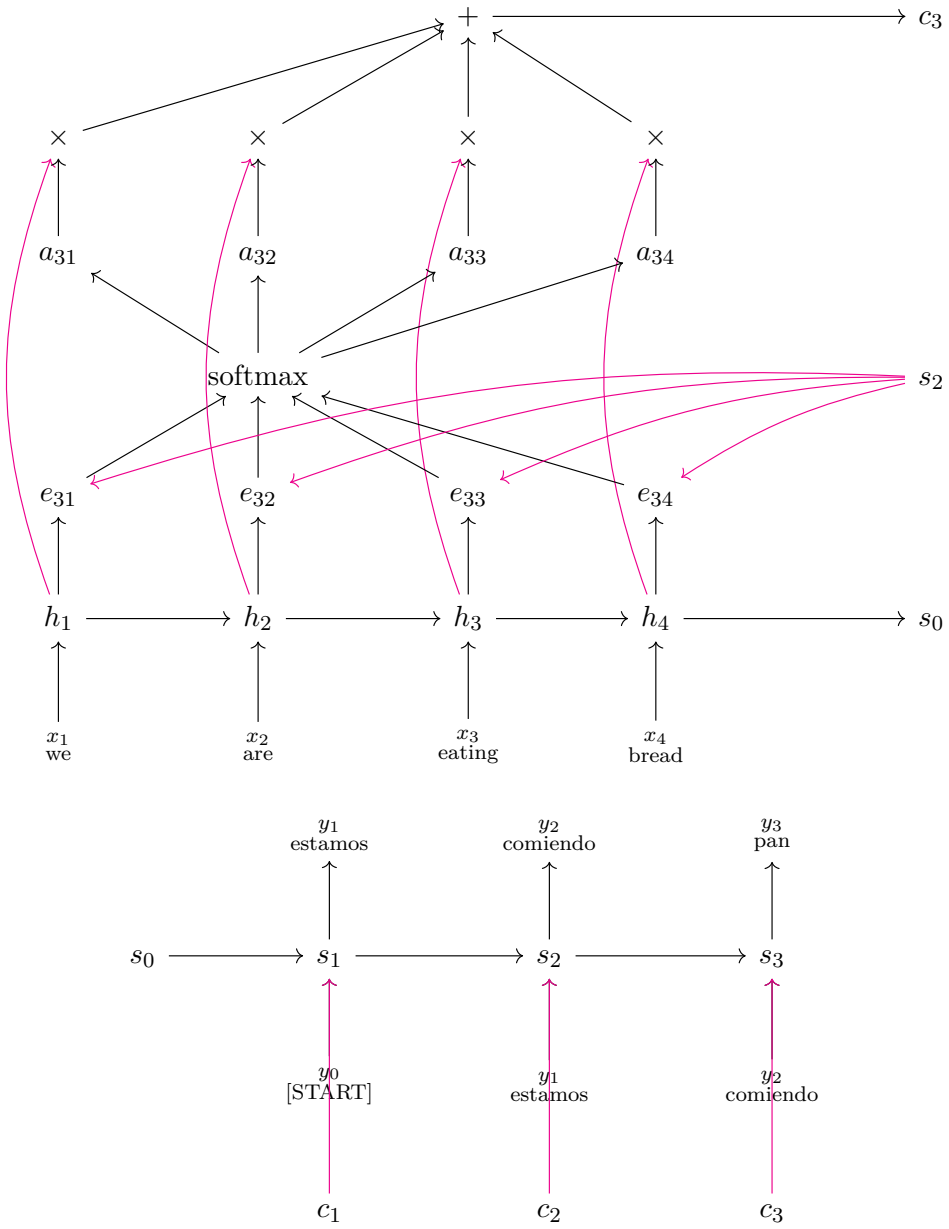

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

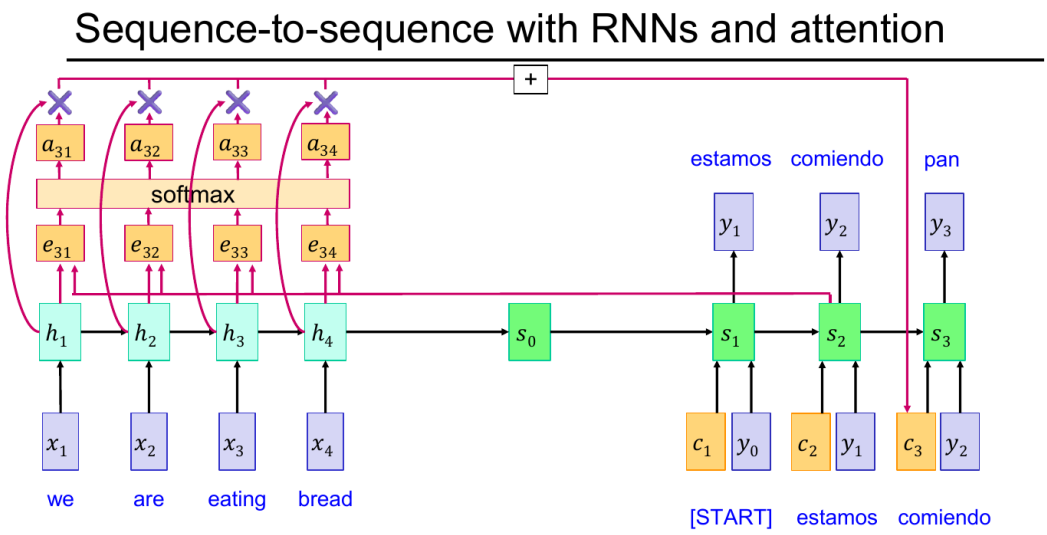

原课件第 57 页：注意力解码的第四步

图示权重 a_{4i}、分数 e_{4i}、上下文 c_4、状态 s_4 与停止标记输出。

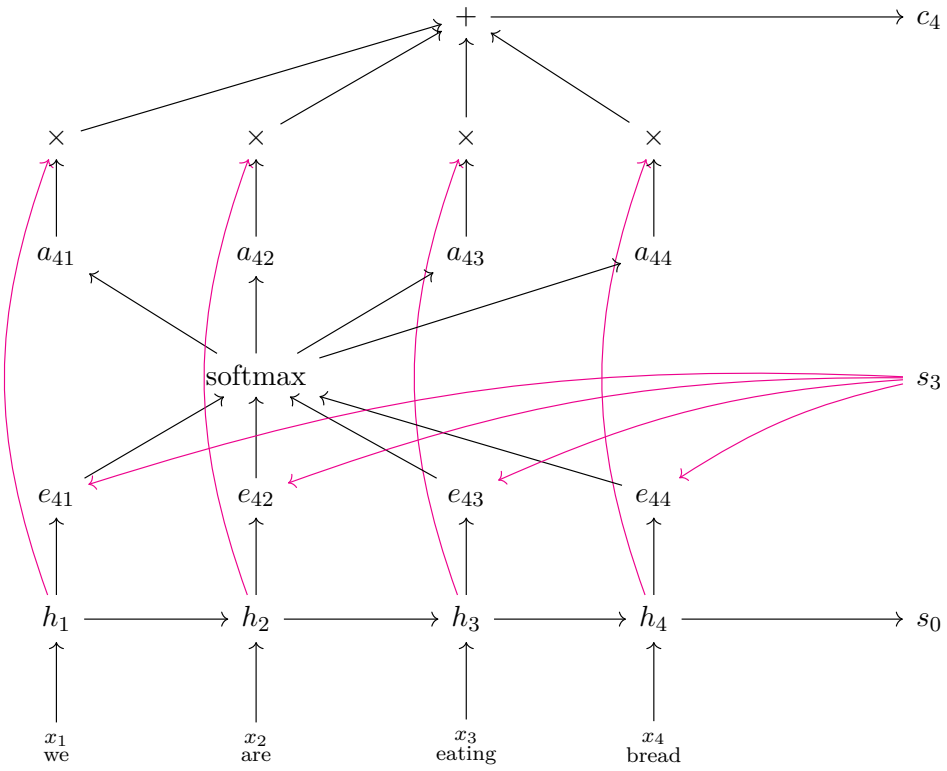

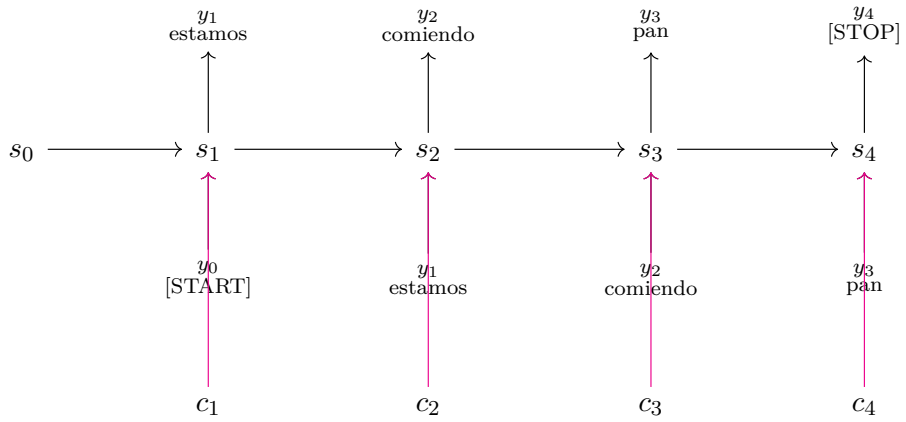

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

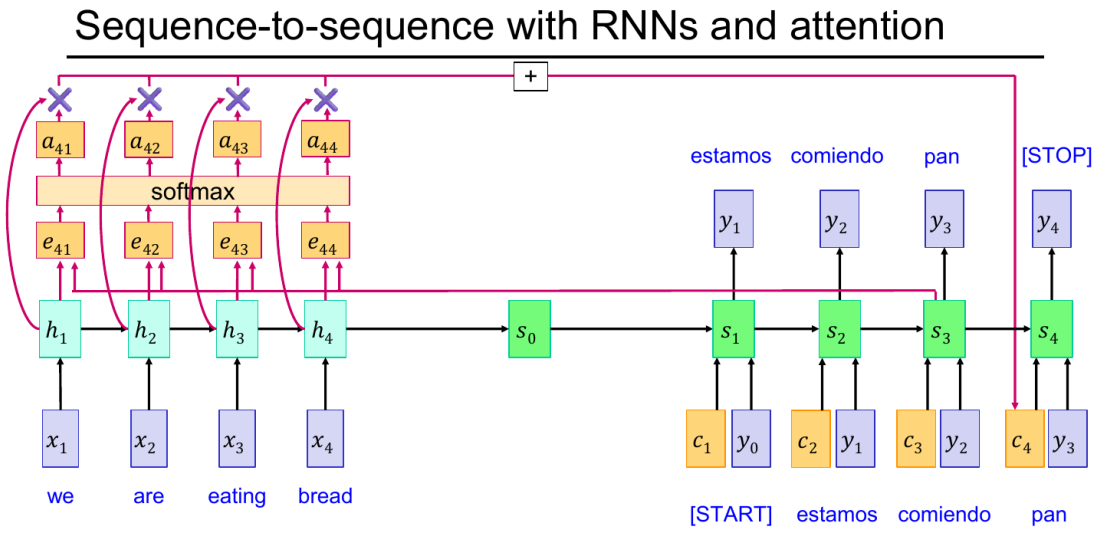

原课件第 58 页：一般时间步的注意力

图中以 e_{ti}, a_{ti} 表示一般时间步的分数和权重，保留编码器与解码器的完整展开。

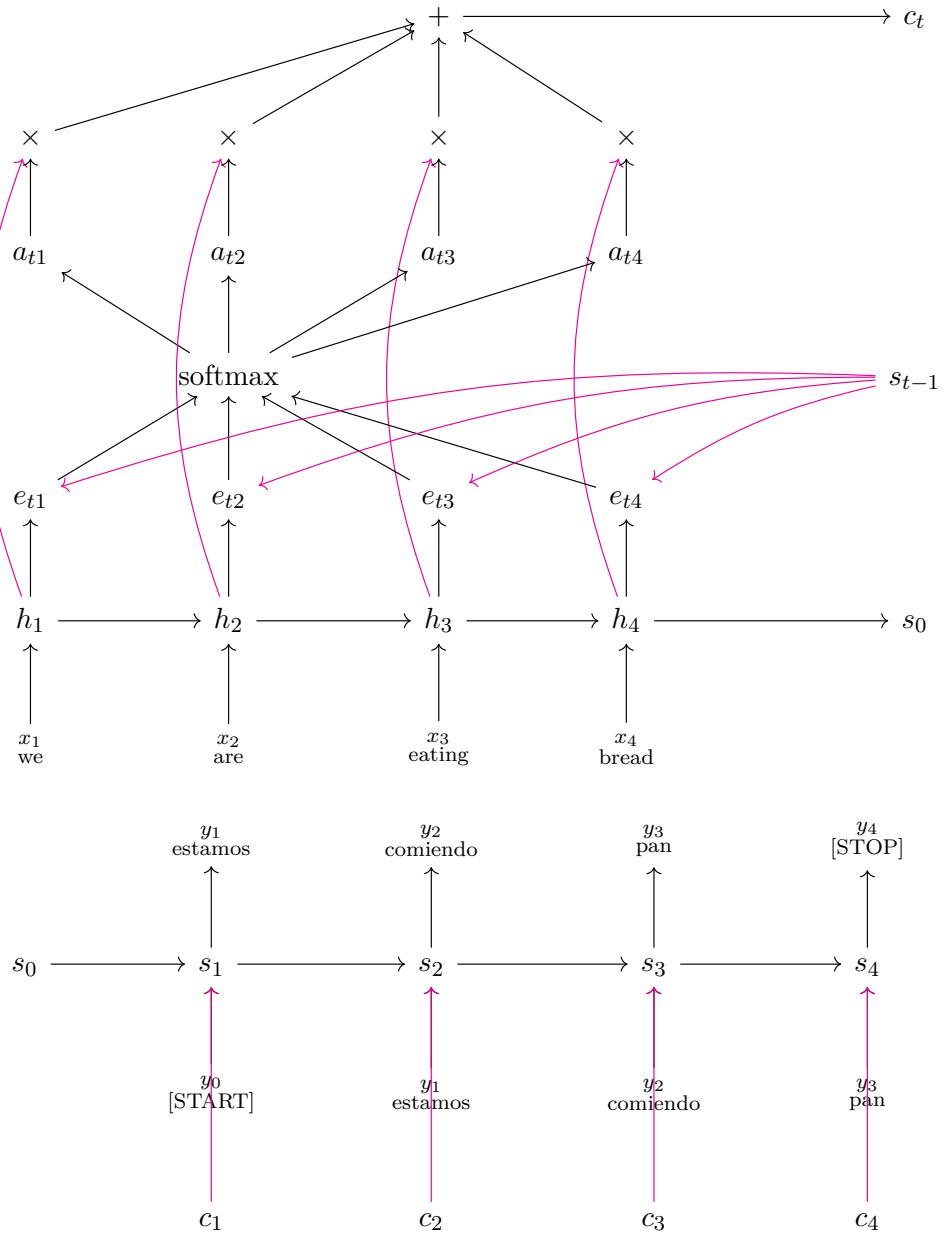

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

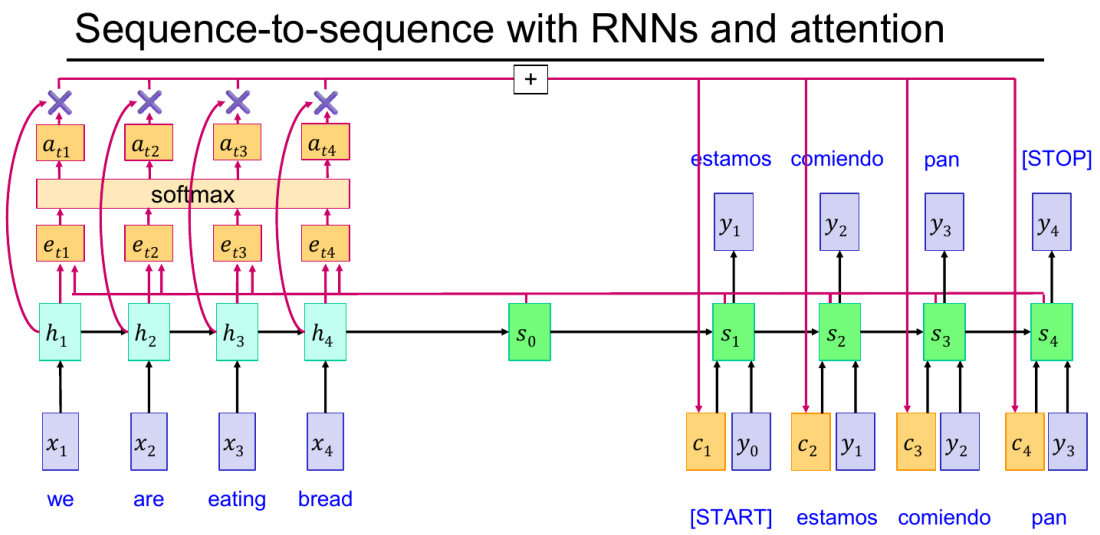

原课件第 59 页：注意力权重可视化

以英语为源语言、法语为目标语言的注意力矩阵展示源语言和目标语言词序相同、词序颠倒以及动词变位不同的情况。来源：D. Bahdanau, K. Cho, Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate*, ICLR 2015。矩阵横轴英语依次为 “The agreement on the European Economic Area was signed in August 1992 . <end>”；纵轴法语依次为 “L’ accord sur la zone économique européenne a été signé en août 1992 . <end>”。两句均意为 “欧洲经济区协定于 1992 年 8 月签署。” 图中品红色框标明源语言与目标语言的词序相同部分；蓝色框标明 European Economic Area 与 zone économique européenne 的词序颠倒；红色框标明 was signed 与 a été signé 的动词形式不同。

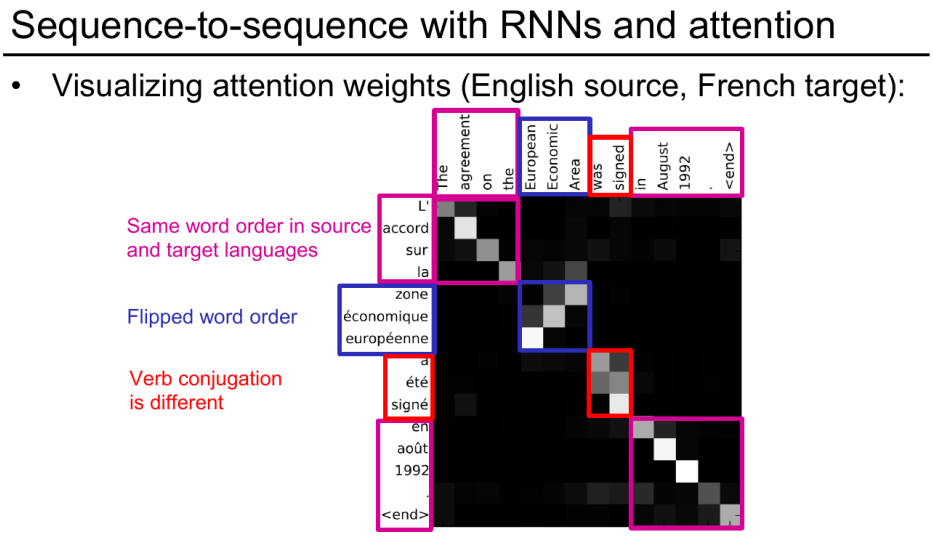

D. Bahdanau, K. Cho, Y. Bengio, Neural Machine Translation by Jointly Learning to Align and Translate, ICLR 2015

原课件第 60 页：推广注意力

解码器没有利用 h_i 构成有序序列这一事实，而是将它们视为无序集合。因此，对于任意一组输入隐向量 $\{h_i\}$，都可以使用类似架构。上下文仍为 $c_t = \sum_i a_{t,i} h_i$。

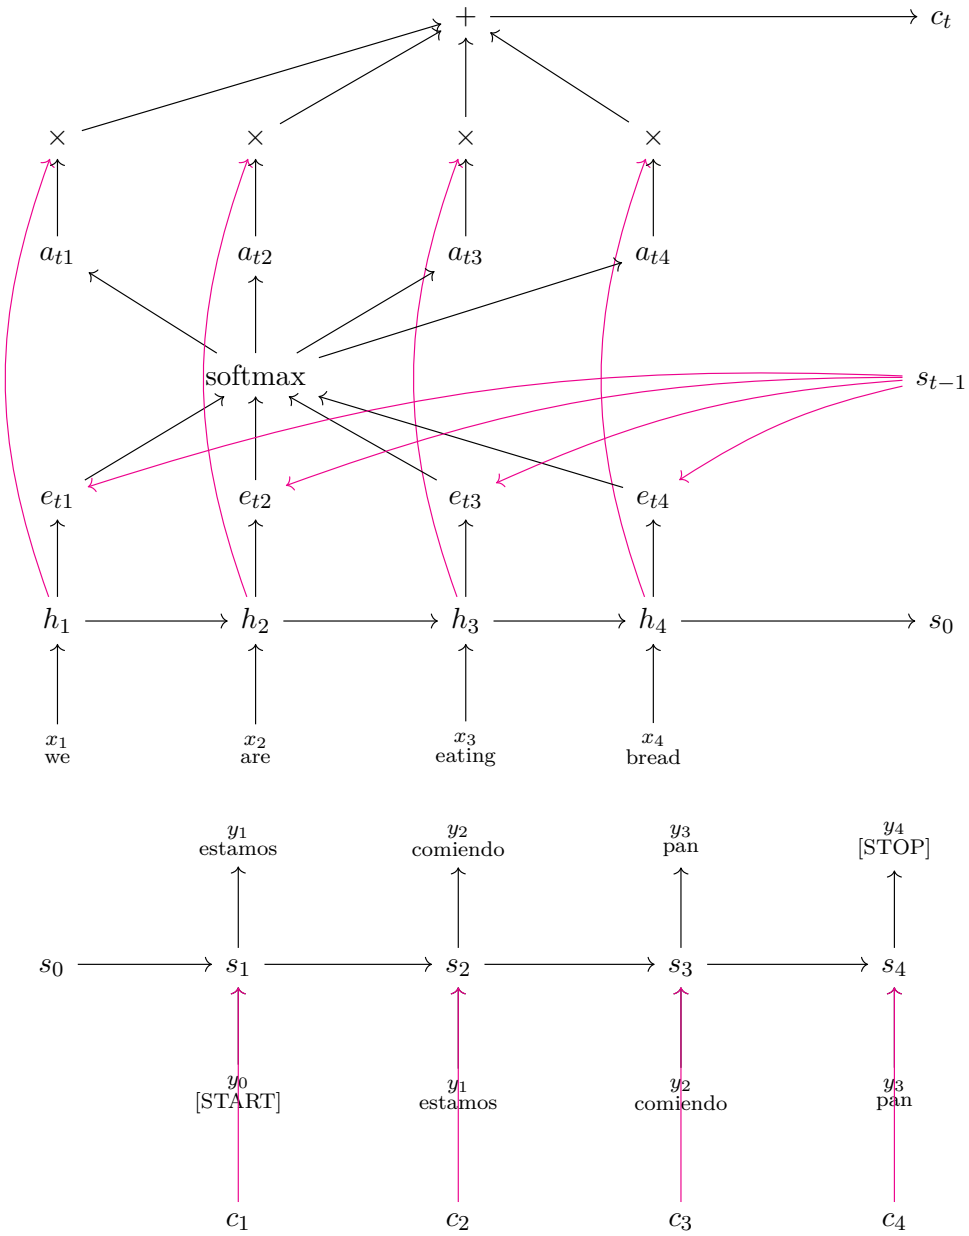

图分为注意力计算与解码展开两部分；第一部分的 c 接入第二部分相应时间步的上下文节点，s_{t-1}（或该页标出的已知状态）为四个对齐分数的共同输入。重排未将图中的复用输入、softmax、乘法或求和视为新增模型。

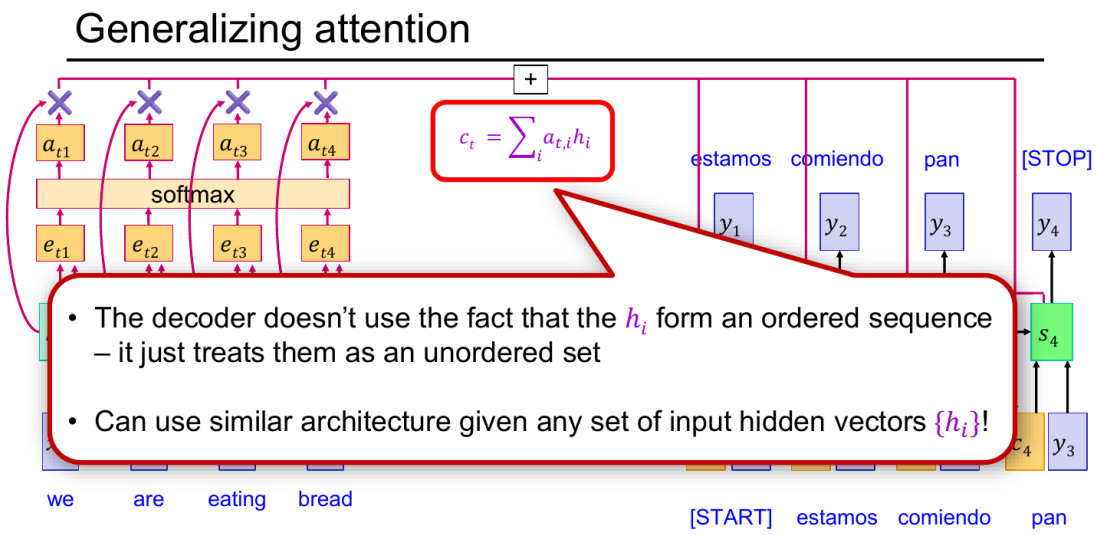

原课件第 61 页：提纲

接下来讨论 Transformer（自注意力、位置编码、视觉 Transformer）、无标签学习、强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 62 页：Transformer

原图为 Transformer 编码器–解码器结构：输入和输出嵌入分别加上位置编码；各层含多头注意力、前馈网络、残差连接和归一化；解码器另有掩码多头注意力；输出经线性层和 softmax 得到概率。图中两侧的模块均重复 N 次。许多幻灯片改编自 J. Johnson。

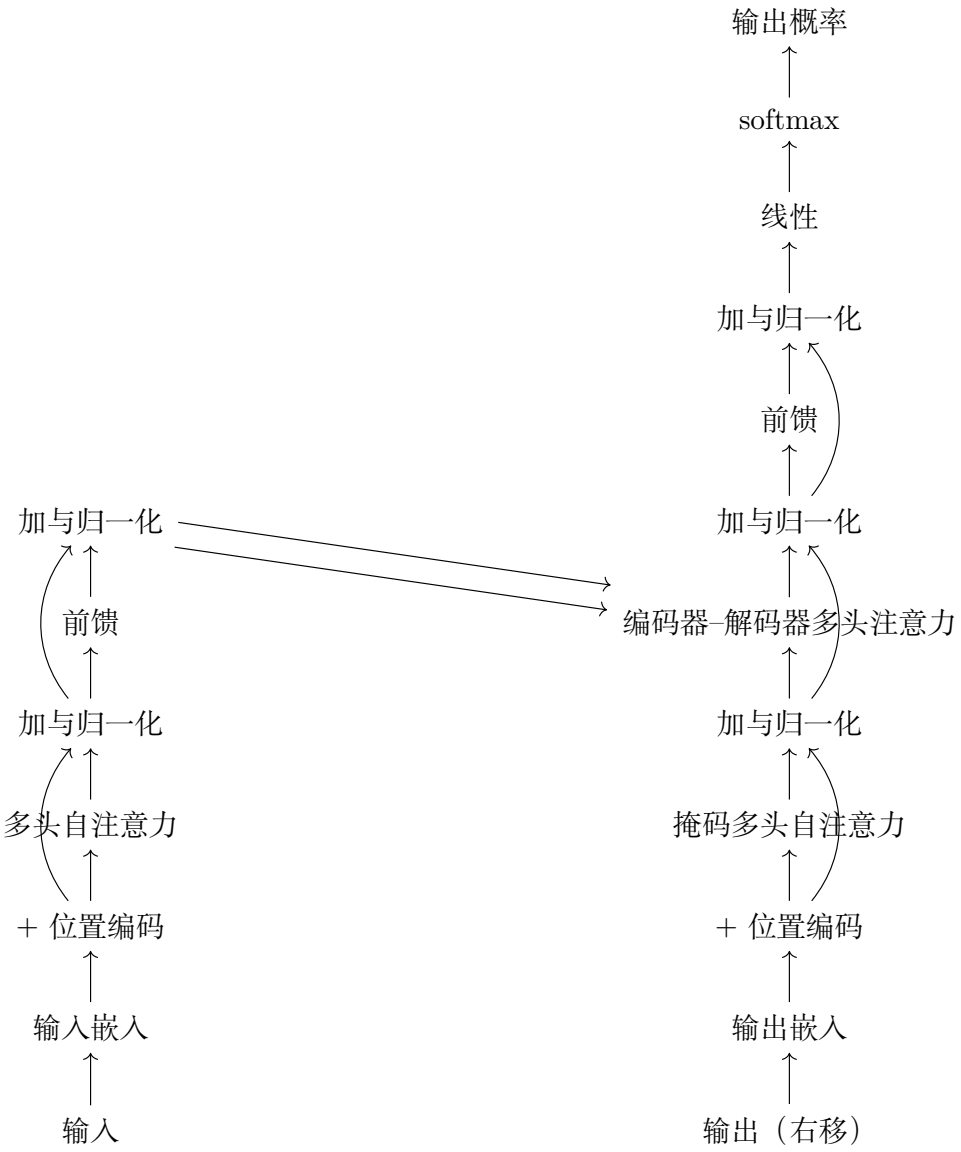

编码器的多头注意力至第二个归一化模块、解码器的掩码多头注意力至第三个归一化模块，各按原图重复 N 次。位置编码为嵌入的加法输入。

Transformers

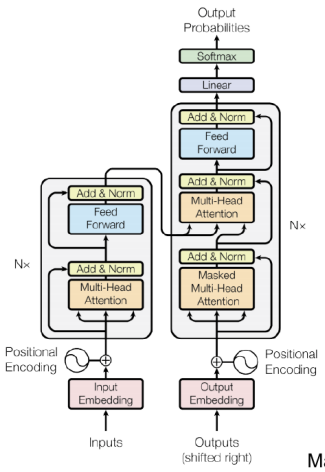

Many slides adapted from J. Johnson

原课件第 63 页：基本 Transformer 模型

这是只使用逐点处理和注意力的序列到序列架构，不含循环单元或卷积。编码器接收整个输入序列，输出等长的编码序列；解码器以编码器输出和先前预测的词元为条件，预测下一个词元。来源：A. Vaswani et al., *Attention Is All You Need*, NeurIPS 2017。

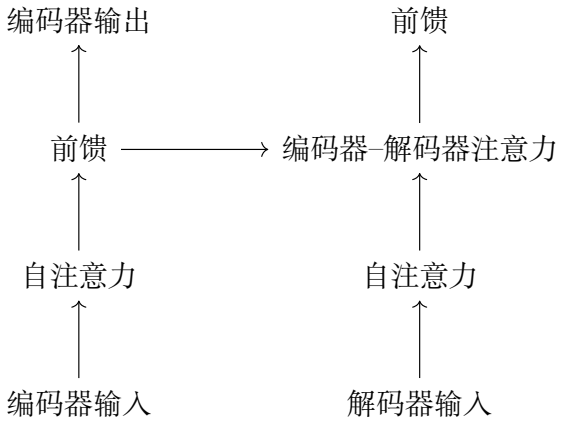

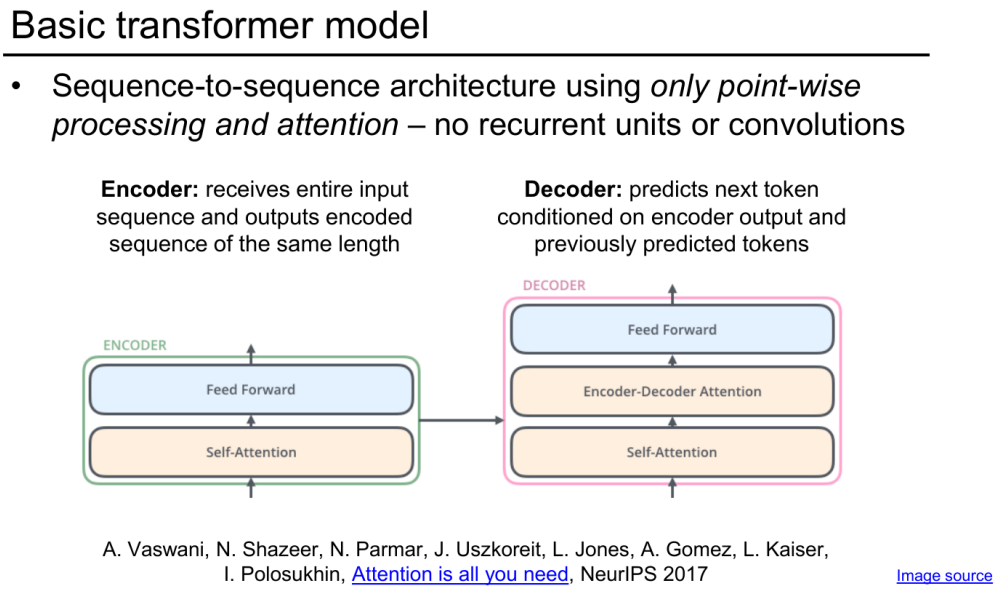

原课件第 64 页：键–值–查询注意力模型

解码器生成查询，描述希望关注的内容；查询与编码器生成的键做点积，得到源词元与查询之间的对齐分数；分数经 softmax 得到注意力权重；最后按权重对编码器生成的值求和。

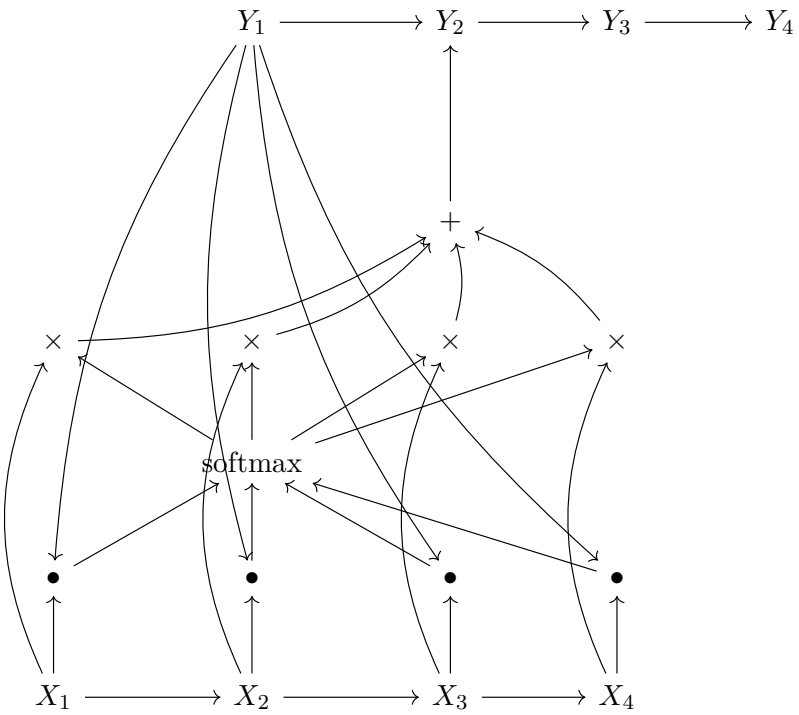

底层为编码器，顶层为解码器；各点积节点同时接收查询与对应键，各乘法节点同时接收 softmax 权重与对应值。

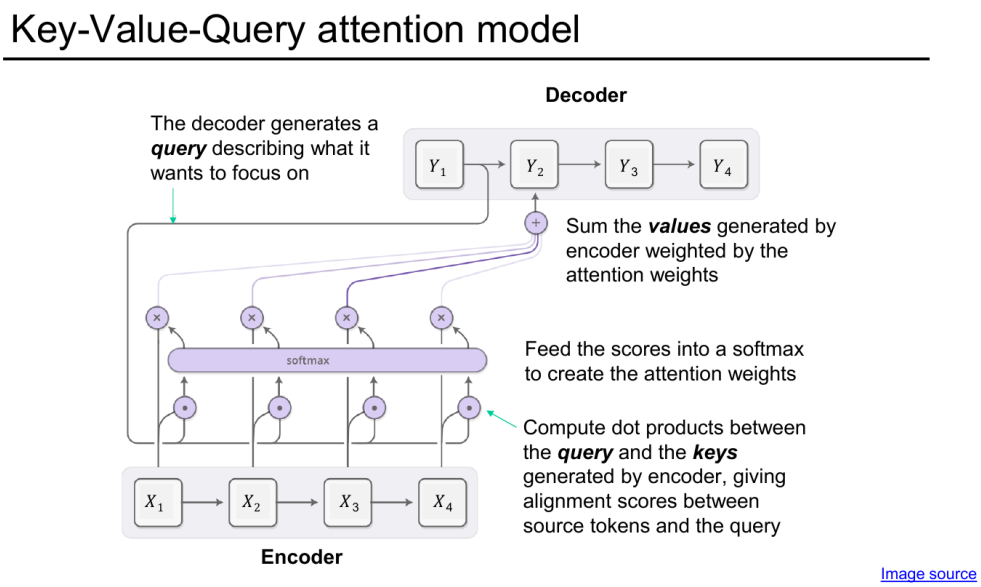

原课件第 65 页：键–值–查询注意力模型（续）

键向量和价值向量分别为 $K = XW_K$、$V = XW_V$。课件另列“查询向量”，但未给出其生成公式。缩放点积注意力写为

$$E_{i,j} = \frac{Q_i \cdot K_j}{\sqrt{D}}, \qquad E = QK^T/\sqrt{D},$$

$$A = \mathrm{softmax}(E, \mathrm{dim} = 1), \qquad Y_i = \sum_j A_{i,j} V_j, \qquad Y = AV,$$

其中 D 是键的维数。图中画有 $Q_i, K_j, V_j, E_{i,j}, A_{i,j}, Y_i$ 的连接；下标与矩阵摆放的对应见下方可编辑重建说明；不据课件推定具体软件张量布局。改编自 J. Johnson。

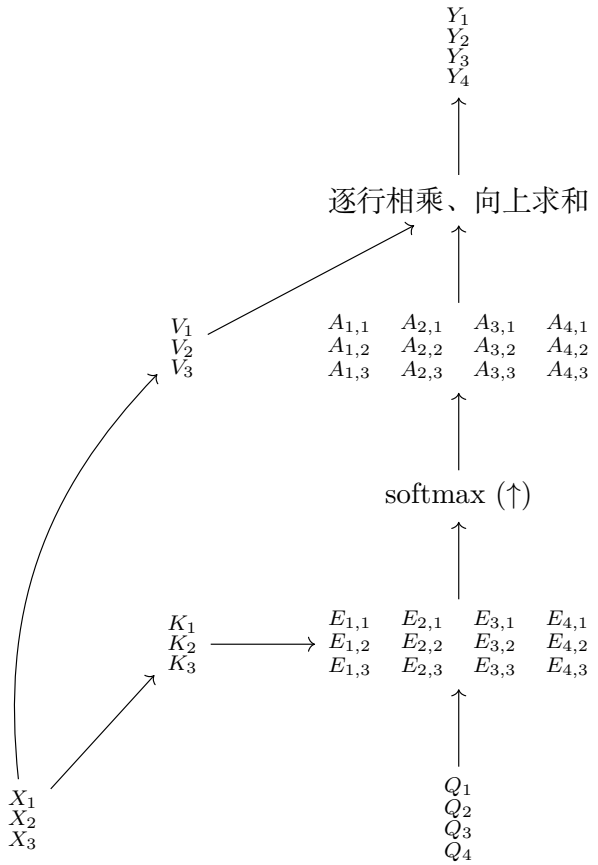

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。本图每个网格的第 j 行第 i 列标作 $E_{i,j}$ 或 $A_{i,j}$，是正文查询行/键列矩阵的转置摆放。$\dim = 1$ 依正文二维矩阵约定沿键索引 j 归一化，具体软件张量布局未给。

Key-Value-Query attention model

- Key vectors: $K = XW_K$
- Value Vectors: $V = XW_V$
- Query vectors
- Similarities: *scaled dot-product attention*

$$E_{i,j} = \frac{(Q_i \cdot K_j)}{\sqrt{D}} \text{ or } E = QK^T/\sqrt{D}$$

(D is the dimensionality of the keys)

- Attn. weights: $A = \text{softmax}(E, \text{dim} = 1)$
- Output vectors:

$$Y_i = \sum_j A_{i,j} V_j \text{ or } Y = AV$$

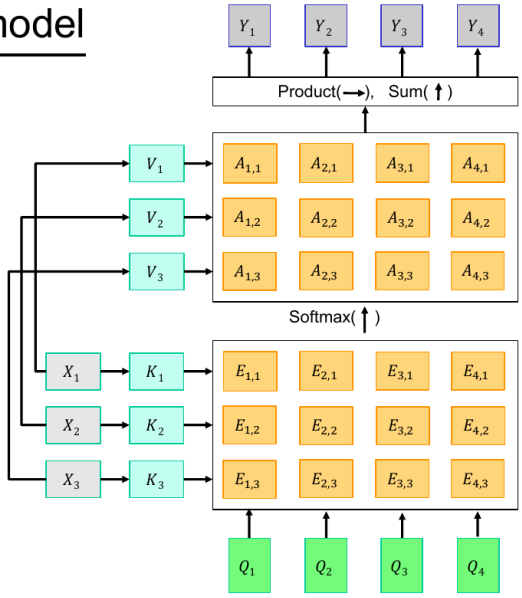

Adapted from J. Johnson

第 3 份课件：Transformer、无标签学习与强化学习

原课件第 1 页：封面

CS 6804：世界模型；Chris Thomas，Virginia Tech 计算机科学系，2026 年秋季。许多幻灯片改编自 Graumann、Kovashka、Lazebnik、Fouhey、Lowe、Seitz、Batra、Forsyth、Fei-Fei Li 和 Hoiem 的材料。

原课件第 2 页：提纲

智能体内部的模型；循环模型（普通 RNN、LSTM、GRU）；瓶颈与注意力；Transformer（自注意力、位置编码、视觉 Transformer）；无标签学习；强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 3 页：Transformer

Transformer 的编码器–解码器架构图与第 2 份第 62 页相同，图中文字及结构见该页译文；许多幻灯片改编自 J. Johnson。

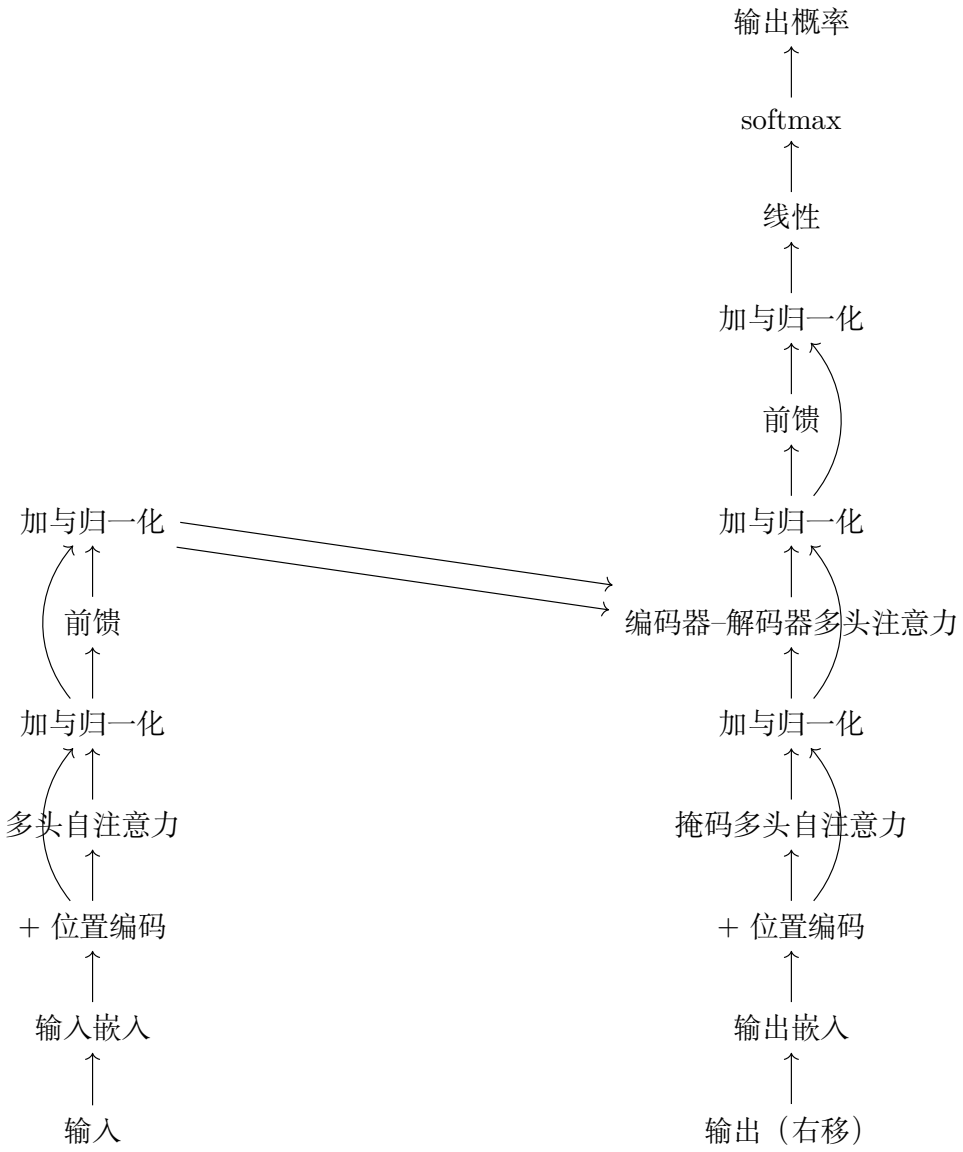

编码器的多头注意力至第二个归一化模块、解码器的掩码多头注意力至第三个归一化模块，各按原图重复 N 次。位置编码为嵌入的加法输入。

原课件第 4 页：基本 Transformer 模型

这是仅使用逐点处理和注意力的序列到序列架构，不含循环单元或卷积。编码器接收整个输入序列并输出等长编码序列；解码器以编码器输出及先前预测词元为条件，预测下一个词元。原图和来源见第 2 份第 63 页。

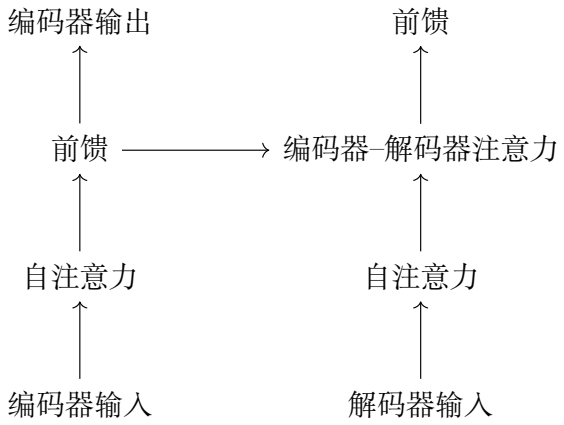

原课件第 5 页：键–值–查询注意力模型

解码器生成描述关注目标的查询，查询与编码器生成的键做点积得到对齐分数；通过 softmax 得到注意力权重，再对编码器生成的值加权求和。原图见第 2 份第 64 页。

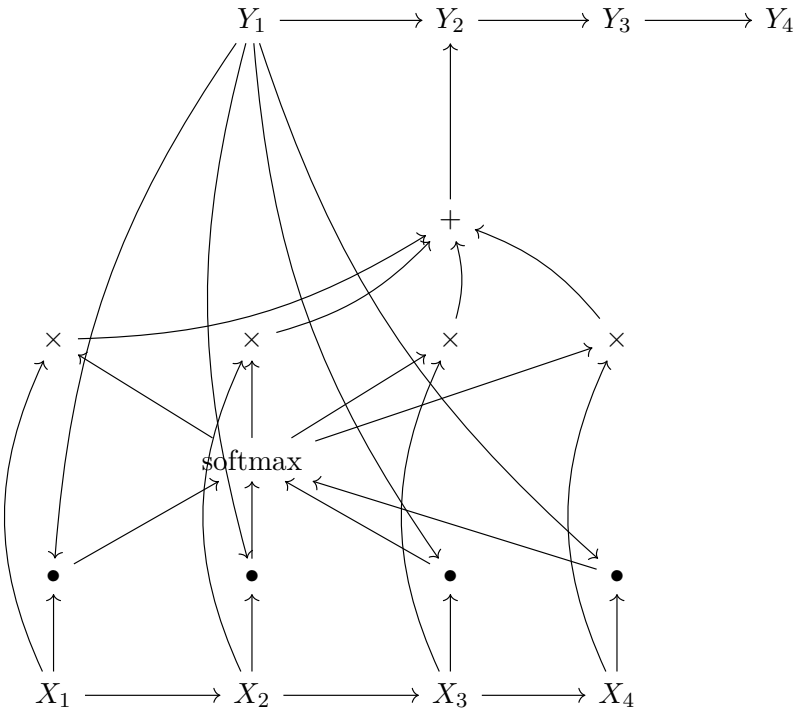

底层为编码器，顶层为解码器；各点积节点同时接收查询与对应键，各乘法节点同时接收 softmax 权重与对应值。

原课件第 6 页：键–值–查询注意力模型（续）

键 $K = XW_K$，值 $V = XW_V$，该页列出查询但未给生成式；令 D 为键的维数，原式为

$$E_{i,j} = \frac{Q_i \cdot K_j}{\sqrt{D}}, \qquad E = QK^T/\sqrt{D},$$

$$A = \mathrm{softmax}(E, \mathrm{dim} = 1), \qquad Y_i = \sum_j A_{i,j} V_j, \qquad Y = AV.$$

原图及下标、归一化维度的待核对事项见第 2 份第 65 页。改编自 J. Johnson。

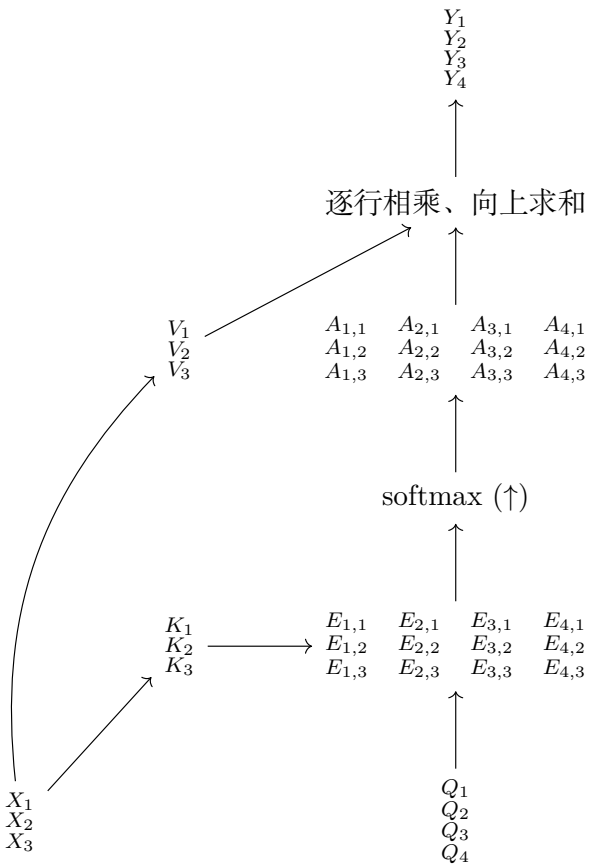

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。本图每个网格的第 j 行第 i 列标作 $E_{i,j}$ 或 $A_{i,j}$，是正文查询行/键列矩阵的转置摆放。$\dim = 1$ 依正文二维矩阵约定沿键索引 j 归一化，具体软件张量布局未给。

原课件第 7 页：键–值–查询注意力模型（续）

改变查询的排列顺序会如何改变输出？改变键 / 值的顺序又会如何改变输出？图中的符号排列沿用第 6 页。改编自 J. Johnson。

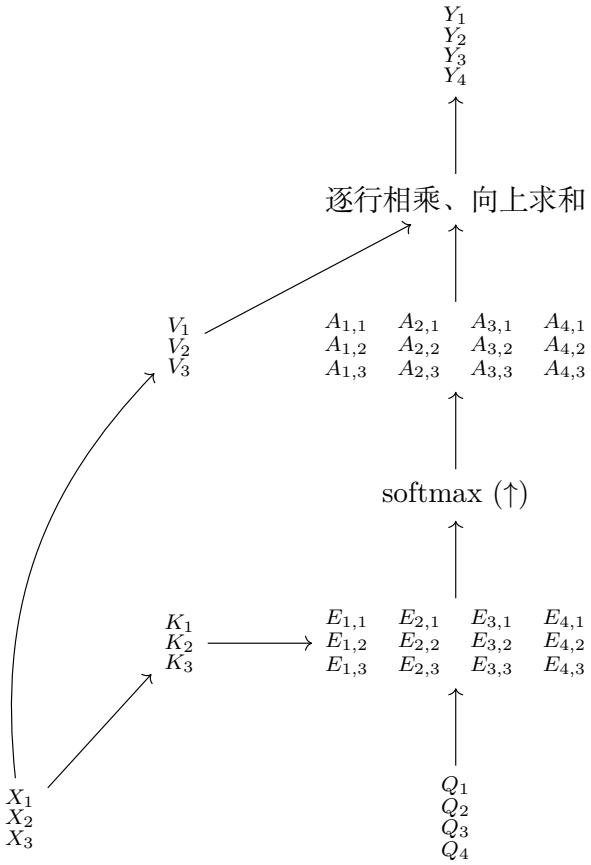

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。本图每个网格的第 j 行第 i 列标作 $E_{i,j}$ 或 $A_{i,j}$，是正文查询行/键列矩阵的转置摆放。$\dim = 1$ 依正文二维矩阵约定沿键索引 j 归一化，具体软件张量布局未给。

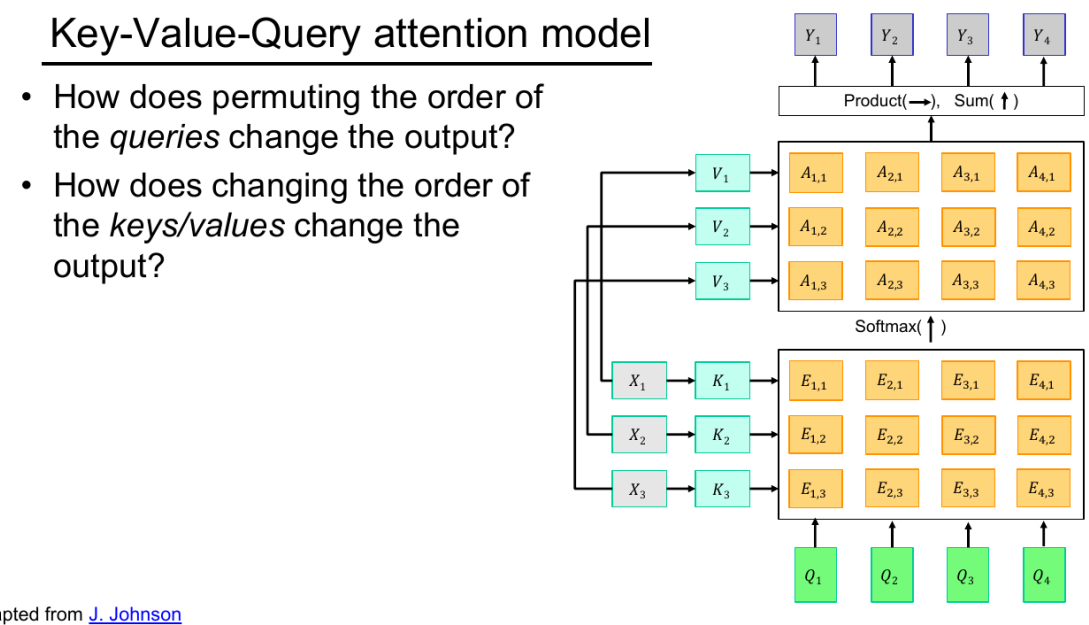

原课件第 8 页：注意力机制

- 编码器自注意力：查询、键、值来自编码器的前一层。
- 解码器自注意力：与解码器未来输出对应的值被掩码遮蔽。
- 编码器–解码器注意力：查询来自解码器前一层，键和值来自编码器输出。

原图标注编码器、解码器、前馈、自注意力和编码器–解码器注意力。

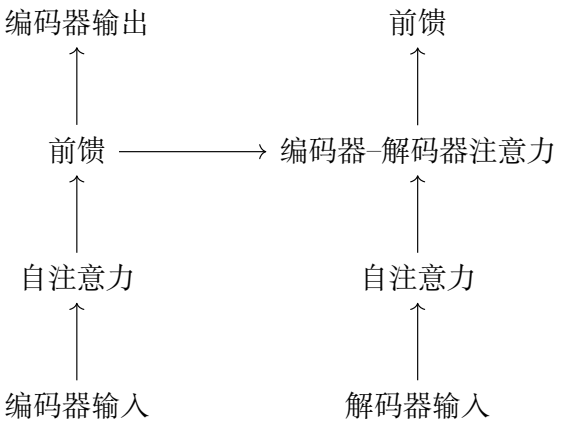

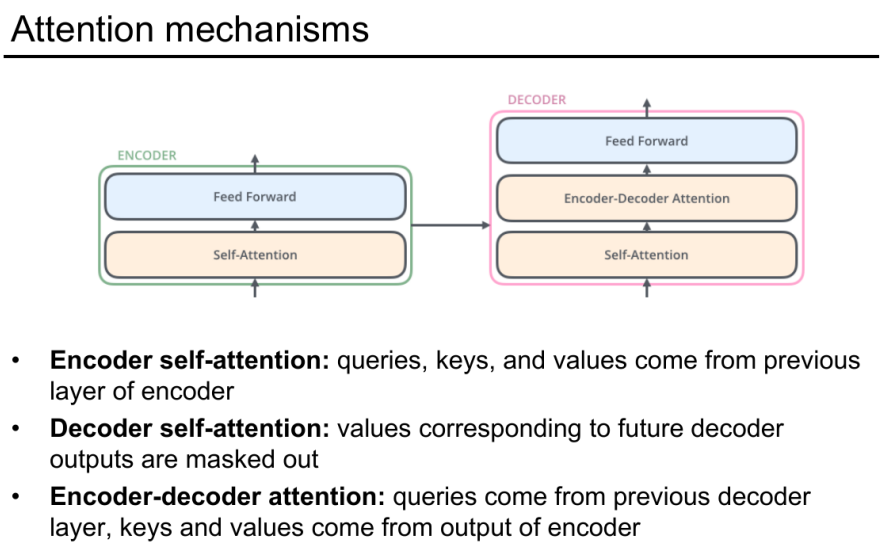

原课件第 9 页：自注意力

自注意力用于捕捉序列内部的上下文。原图比较两句：“动物没有穿过街道，因为它太累了”和“动物没有穿过街道，因为它太宽了”。编码“它”时，前者应关注“动物”，后者应关注“街道”。

Self-attention

- Used to capture context *within the sequence*

As we are encoding “it”, we should focus on “the animal”

As we are encoding “it”, we should focus on “the street”

Image source

原课件第 10 页：自注意力层

每个输入向量对应一个查询：$Q = XW_Q$、$K = XW_K$、$V = XW_V$。相似度、注意力权重和输出使用第 6 页同样的公式。图中将 Q_i, K_j, V_j 相连，并标出 softmax 向上、乘积向右与求和向上；索引约定仍待核对。改编自 J. Johnson。

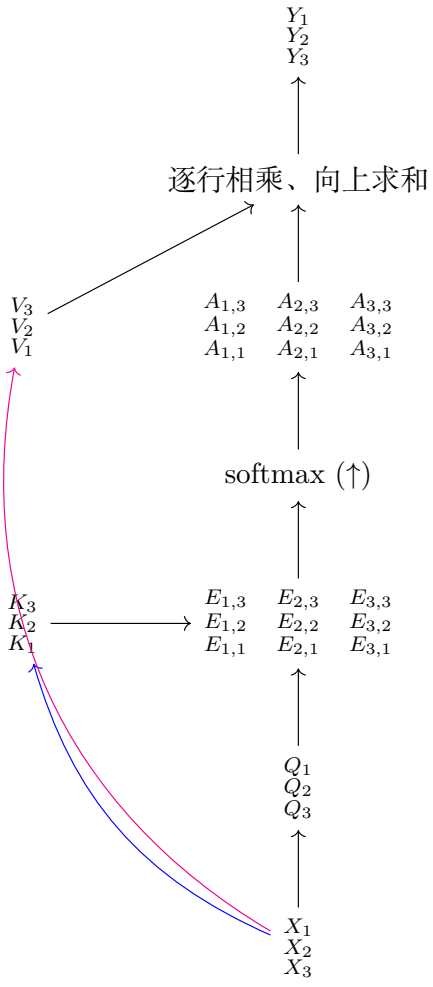

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。

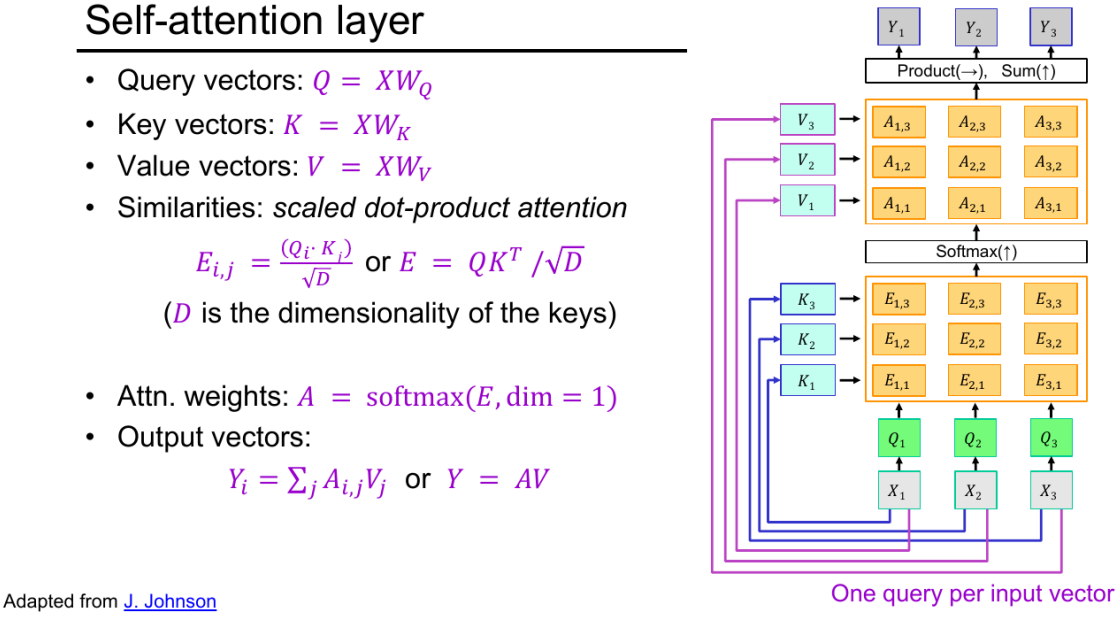

原课件第 11 页：掩码自注意力层

解码器不应在输出序列中“向前看”。图示输入 `<START> This is` 与输出 `This is ...` 及注意力计算。改编自 J. Johnson。

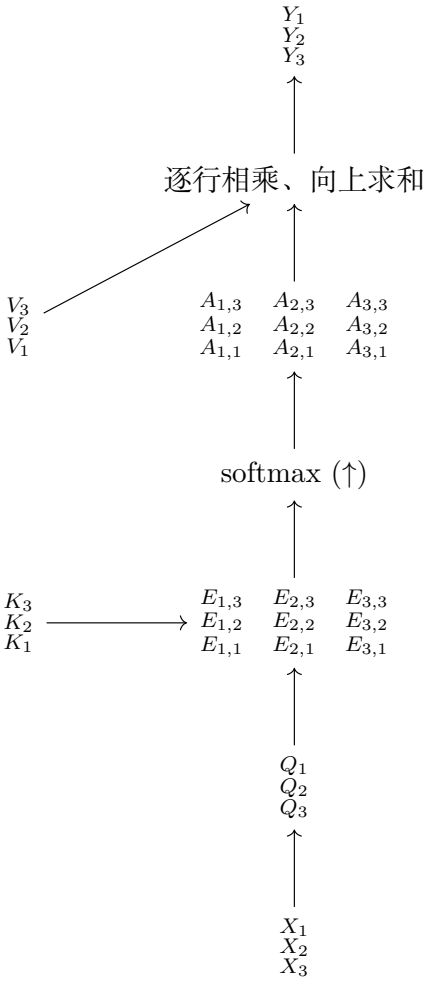

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。本页源图未画出 X 至 K, V 的外侧连线，未在此补画。输入依次为 `<START> This is`，输出标为 `This is ...`。

Masked self-attention layer

- The decoder should not “look ahead” in the output sequence

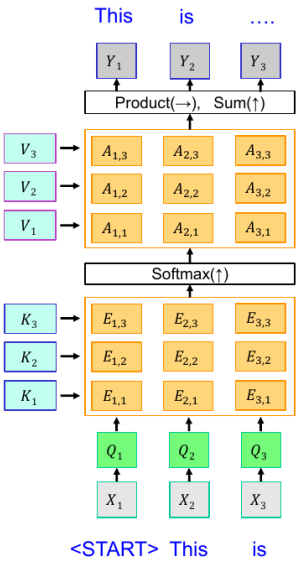

Adapted from J. Johnson

原课件第 12 页：掩码自注意力层（续）

原图展开查询、键和值的连接，继续说明解码器不应看见未来输出。改编自 J. Johnson。

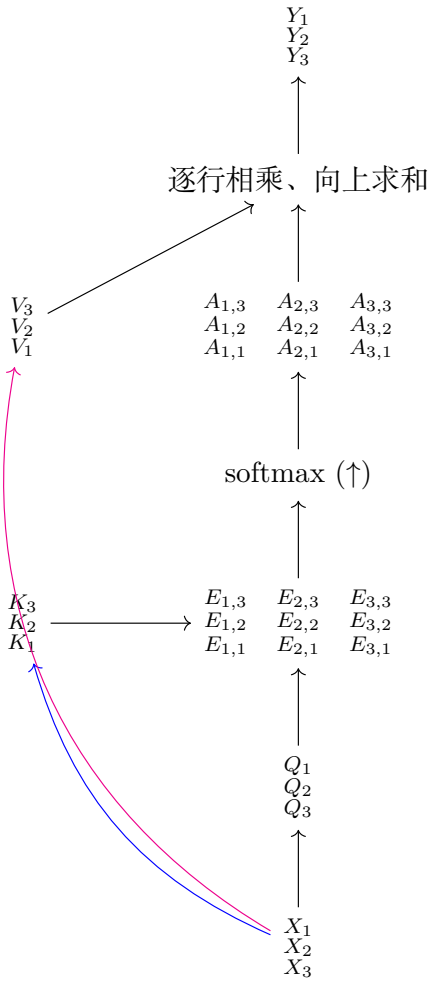

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。

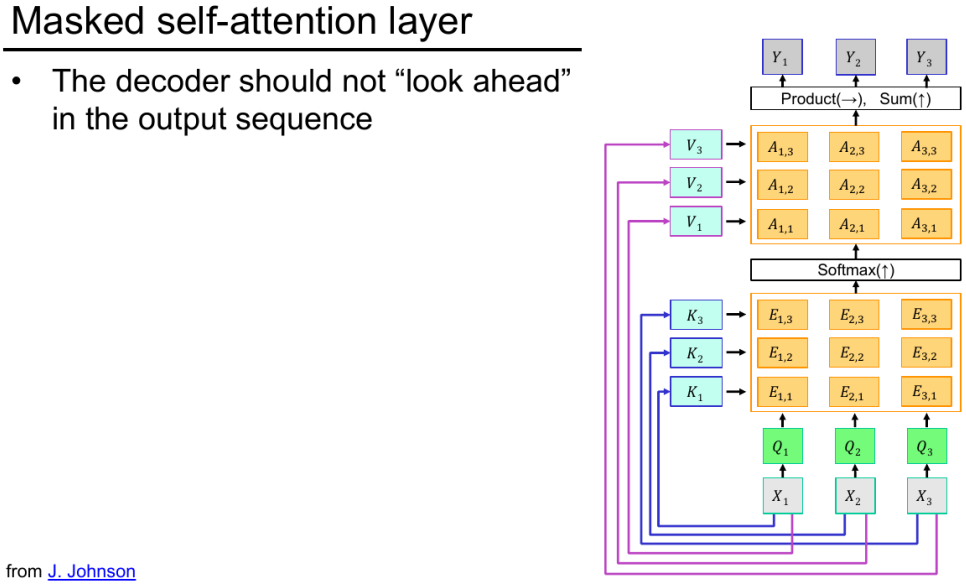

原课件第 13 页：掩码自注意力层（续）

原图将未来位置的相似度置为 $-\infty$，对应 softmax 后的注意力权重为 0，以阻止解码器向前看。改编自 J. Johnson。

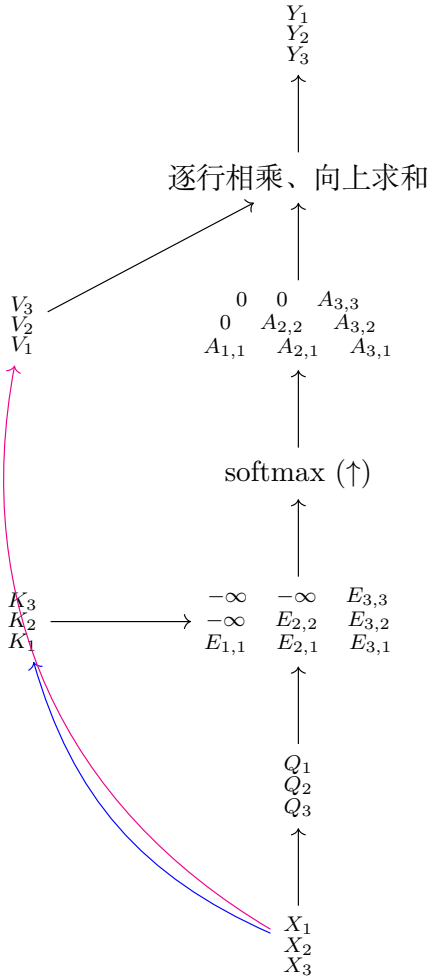

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。

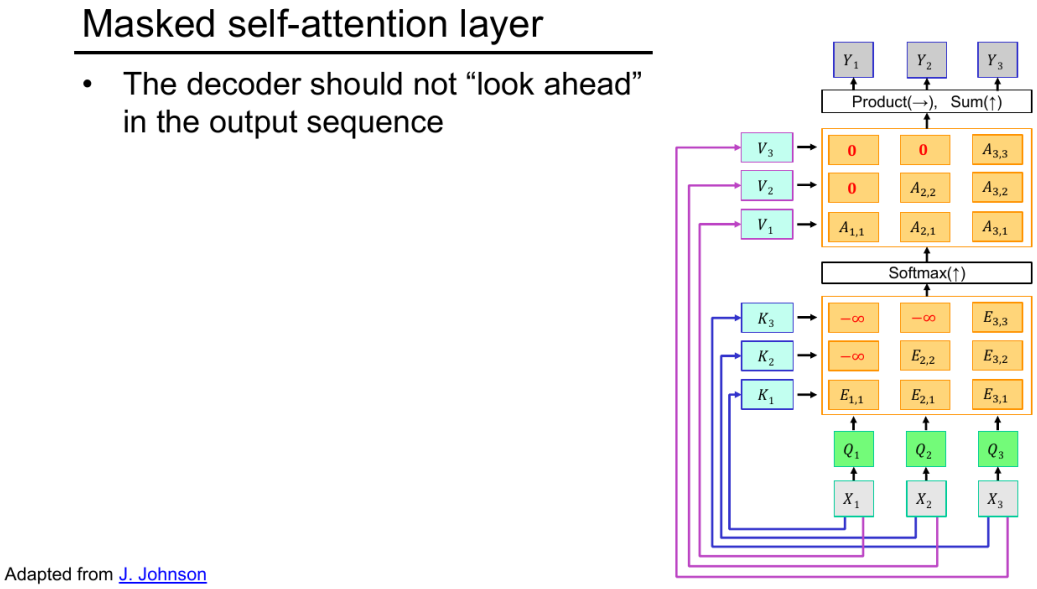

原课件第 14 页：注意力机制总结

编码器自注意力的查询、键和值来自编码器前一层；解码器自注意力屏蔽未来输出对应的值；编码器–解码器注意力的查询来自解码器前一层，键和值来自编码器输出。原图标明编码器和解码器各有 N 个 Transformer 块。

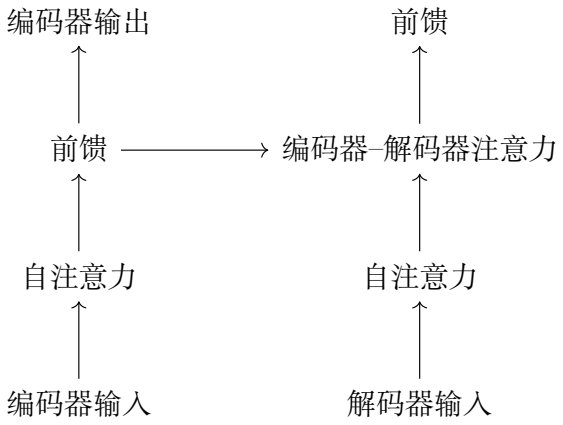

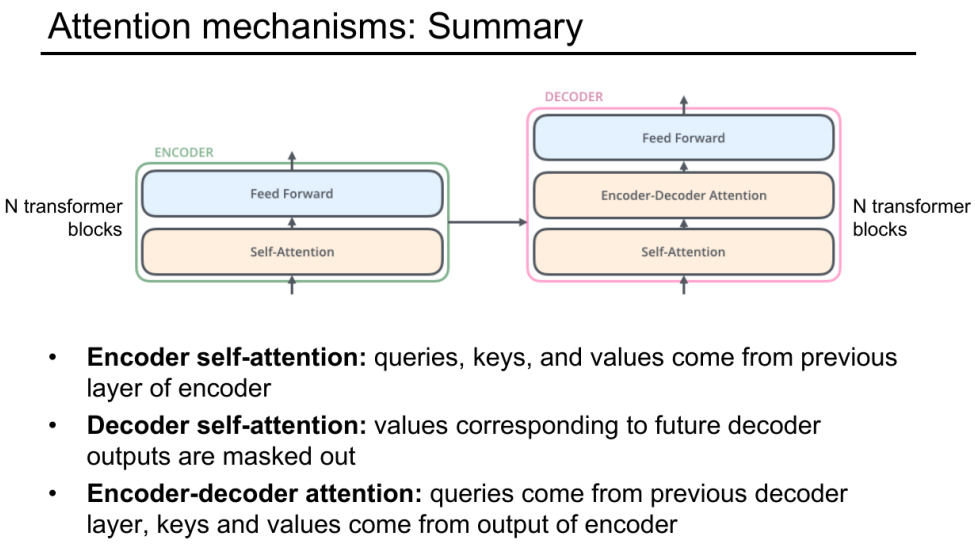

原课件第 15 页：Transformer 架构细节

图中编码器和解码器包含输入 / 输出嵌入、位置编码、多头注意力、前馈网络、残差连接及归一化，解码器的自注意力带掩码；最后经线性层和 softmax 得到输出概率。来源：A. Vaswani et al., *Attention Is All You Need*, NeurIPS 2017。

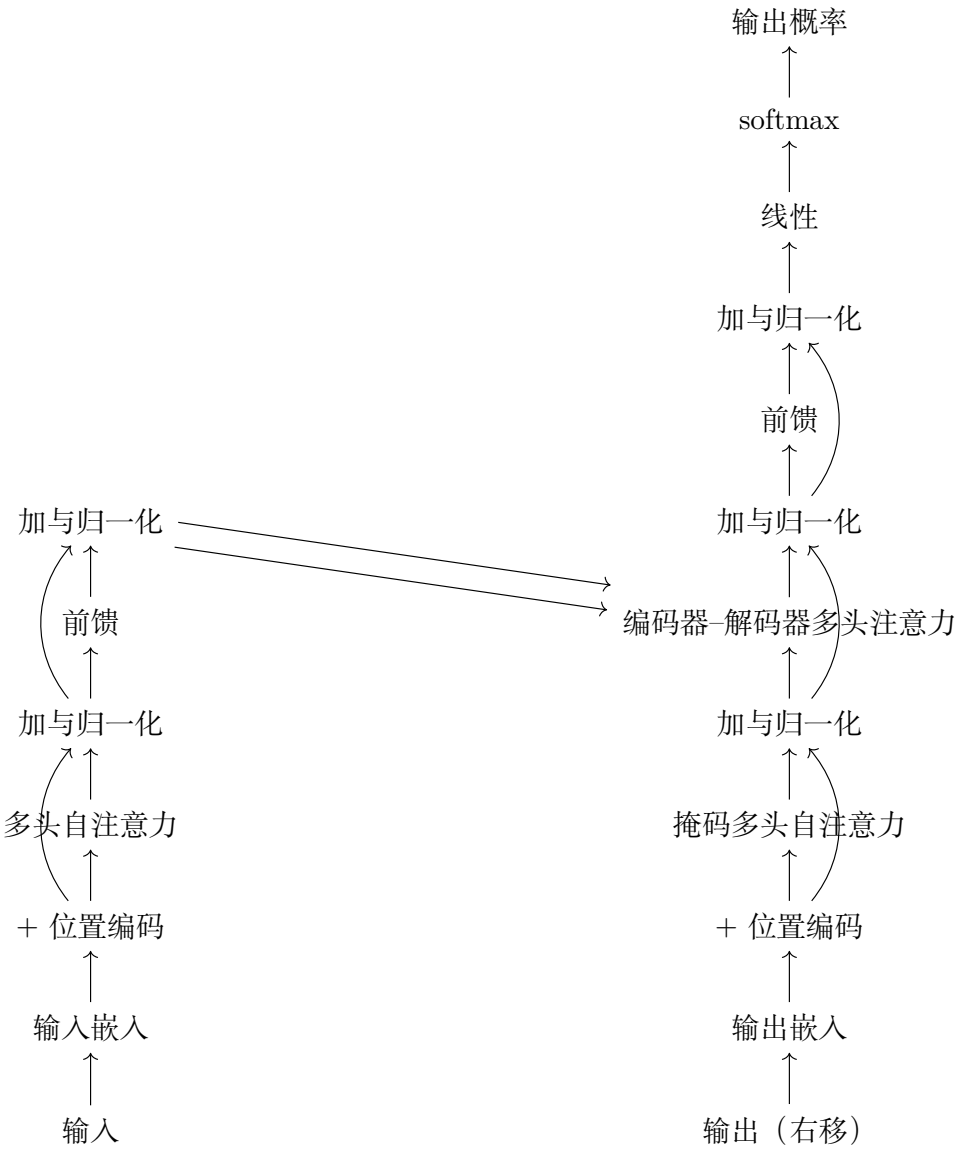

编码器的多头注意力至第二个归一化模块、解码器的掩码多头注意力至第三个归一化模块，各按原图重复 N 次。位置编码为嵌入的加法输入。

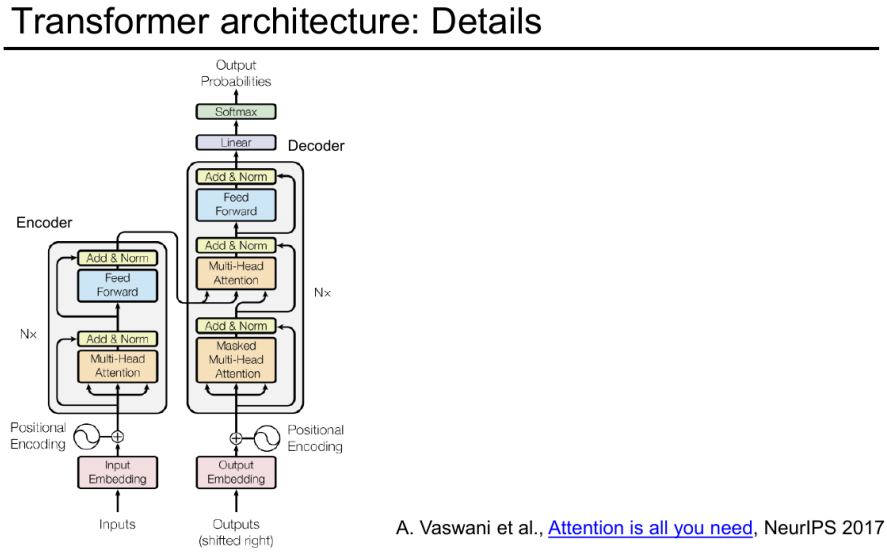

原课件第 16 页：位置编码

为向 Transformer 提供词元顺序信息，在每个输入位置上加上基于正弦、余弦的位置函数：

$$PE(\text{pos}, 2i) = \sin\left(\frac{\text{pos}}{10000^{2i/d}}\right),$$
$$PE(\text{pos}, 2i+1) = \cos\left(\frac{\text{pos}}{10000^{2i/d}}\right).$$

图中纵轴为位置，横轴为嵌入维度。

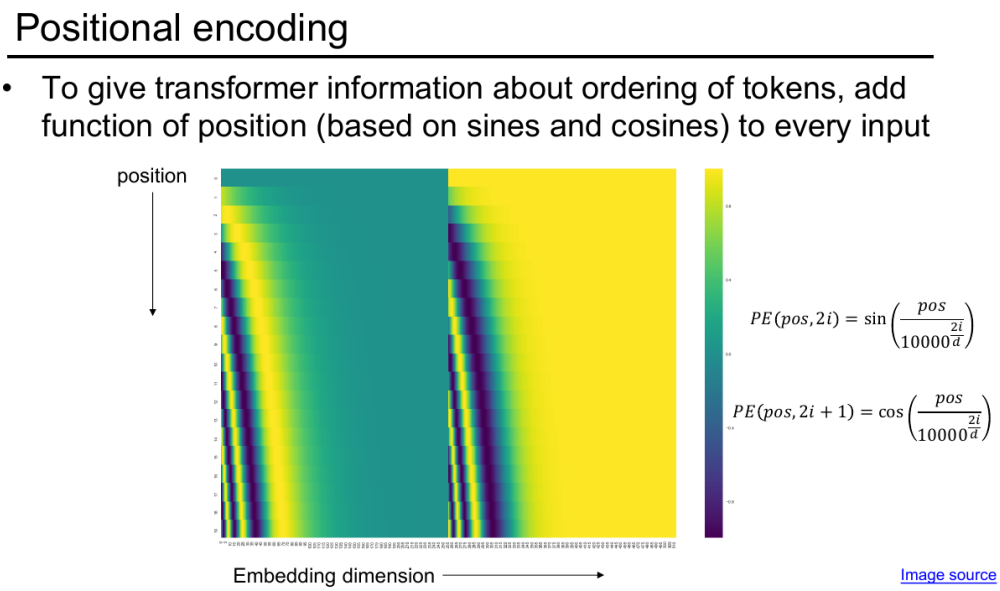

原课件第 17 页：多头注意力

对 Q, K, V 的不同线性投影并行运行 h 个注意力模型，拼接结果后再作线性投影。直观上，这使模型能够关注不同位置的不同类型信息。图中依次标出线性投影、缩放点积注意力、拼接和线性变换。

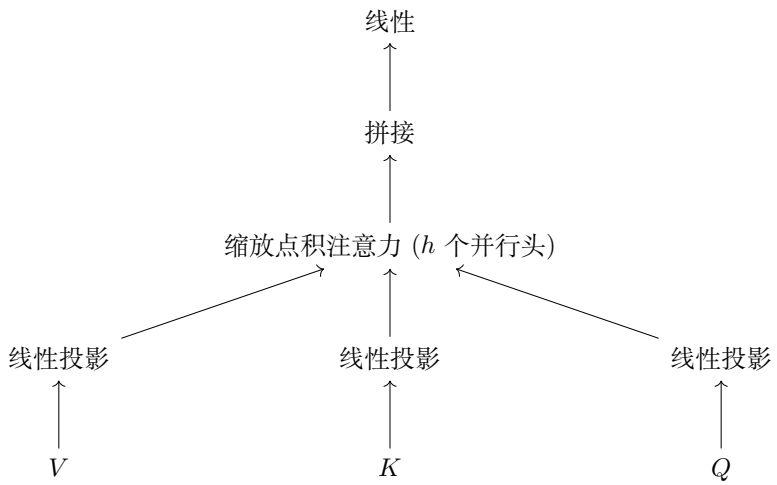

Multi-head attention

- Run h attention models in parallel on top of different linearly projected versions of Q, K, V; concatenate and linearly project the results
- Intuition: enables model to attend to different kinds of information at different positions (see visualization tool)

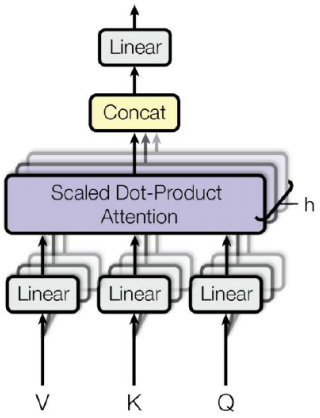

原课件第 18 页：Transformer 块

层归一化：给定形状均为 D 的 $h_1, \ldots, h_N$，尺度 γ 和偏移 β 也为 D 维；原页给出

$$\mu_i = \frac{1}{D}\sum_j h_{i,j}, \qquad \sigma_i = \left(\frac{1}{D}\sum_j (h_{i,j}-\mu_i)^2\right)^{1/2},$$

$$z_i = \frac{h_i - \mu_i}{\sigma_i}, \qquad y_i = \gamma * z_i + \beta.$$

其中 μ_i, σ_i 为标量，$*$ 为原页记号。图中两个残差连接分别包围对每个向量独立作用的 MLP 和使所有向量相互作用的多头注意力。来源：Ba et al., 2016。原式未显示数值稳定项，按原样保留。

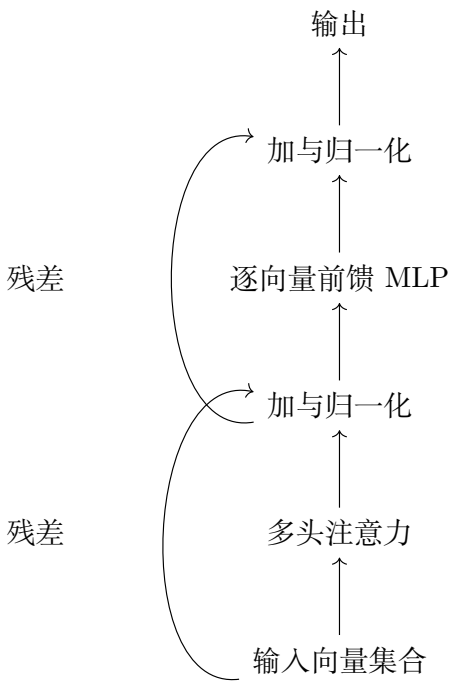

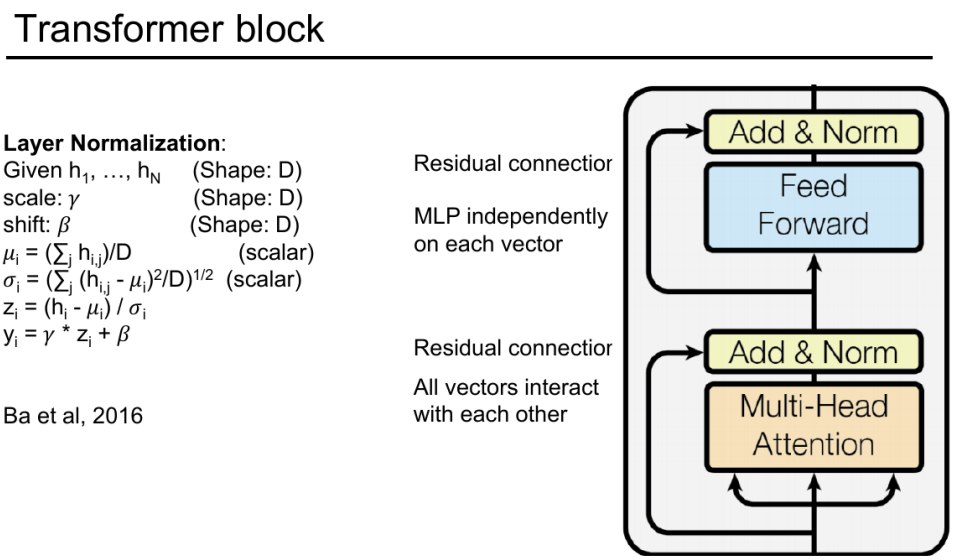

原课件第 19 页：回看 Transformer 架构

原图再次展示编码器和解码器的整体结构，见本份第 15 页。来源：A. Vaswani et al., *Attention Is All You Need*, NeurIPS 2017。

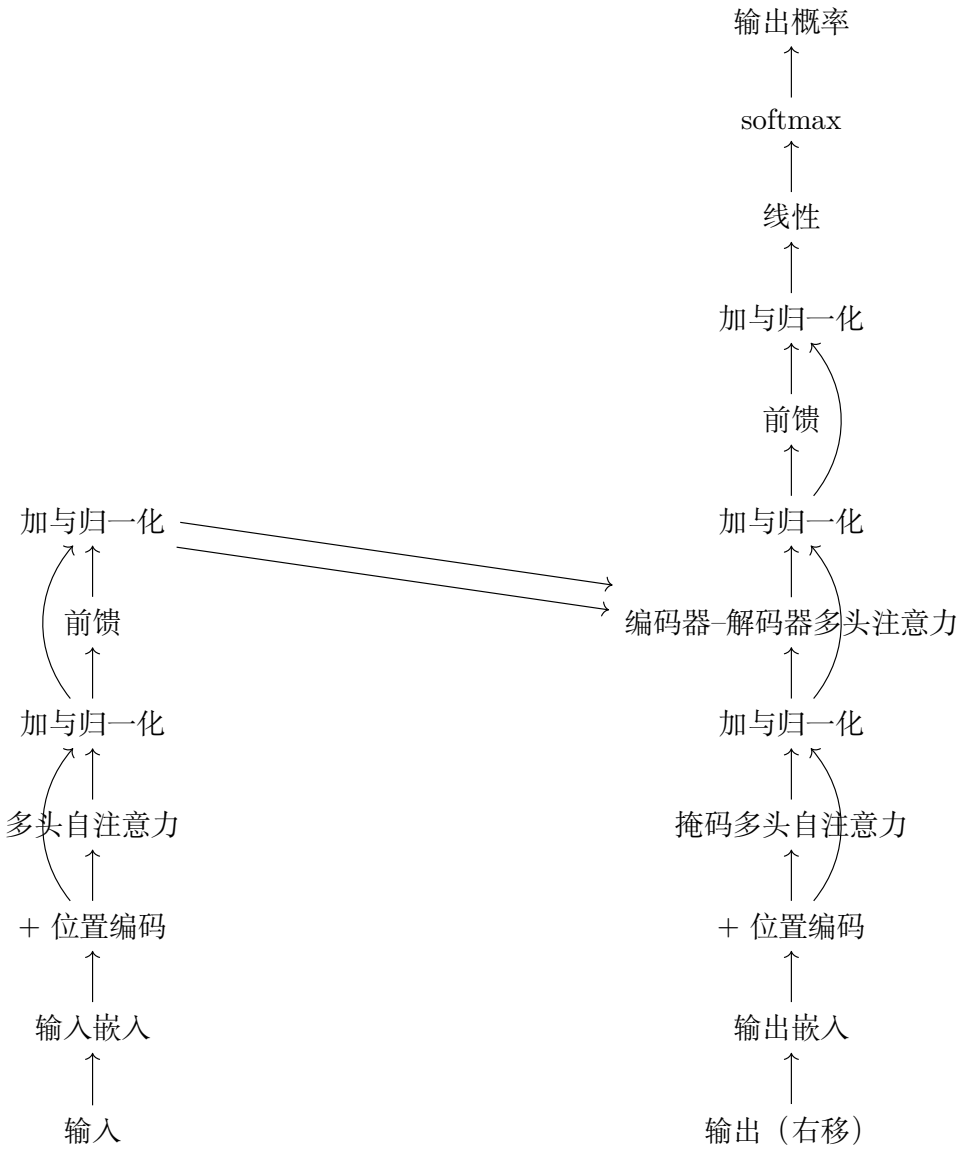

编码器的多头注意力至第二个归一化模块、解码器的掩码多头注意力至第三个归一化模块，各按原图重复 N 次。位置编码为嵌入的加法输入。

原课件第 20 页：处理序列的不同方式

原图比较每层复杂度、串行操作数及最大路径长度。n 是序列长度，d 为表示维数，k 是卷积核大小，r 是受限自注意力的邻域大小：

层类型	每层复杂度	串行操作	最大路径长度
自注意力	$O(n^2 d)$	$O(1)$	$O(1)$
循环	$O(nd^2)$	$O(n)$	$O(n)$
卷积	$O(knd^2)$	$O(1)$	$O(\log_k n)$
受限自注意力	$O(rnd)$	$O(1)$	$O(n/r)$

译注：这是课件所比较结构的量级表。无膨胀、固定步长的局域卷积堆叠，其感受野随层数仅线性增长；表中对数最大路径依赖具体卷积布局，不能推广至任意卷积网络。表也不等于完整模型所有投影、优化和训练的成本。

Different ways of processing sequences

Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the representation dimension, k is the kernel size of convolutions and r the size of the neighborhood in restricted self-attention.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

原课件第 21 页：Transformer 的优缺点

- RNN 处理有序序列；优点是原则上不受固定上下文长度限制，一层 RNN 后 h_T 能“看到”整个序列。缺点是隐状态须依次计算，不能并行；隐状态表达能力有限。
- 一维卷积网络用于多维网格；优点是训练时各输出可并行计算，缺点是须堆叠多层卷积才能使输出“看到”整个序列。
- Transformer 处理向量集合；优点是适合长序列，一层自注意力后每个输出都能“看到”所有输入，训练时各输出可以并行计算；缺点是占用大量内存，注意力算子的成本随输入大小呈二次增长。

RNN：

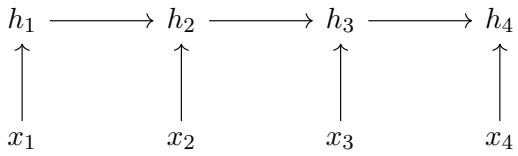

一维卷积：

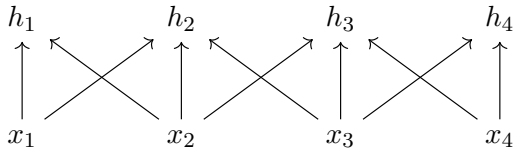

Transformer：

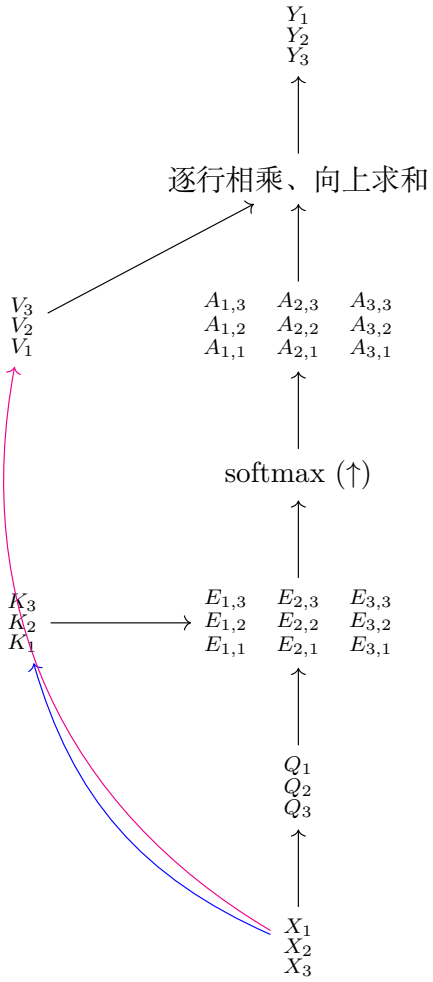

原网格各个标号在此按原行列顺序排成可编辑数组；组合箭头作用于整个数组，不表示只选取中央某个矩阵元素。左侧向量按行对应，底部查询按列对应；原图几何、颜色和分组边框仍保留在截图中。

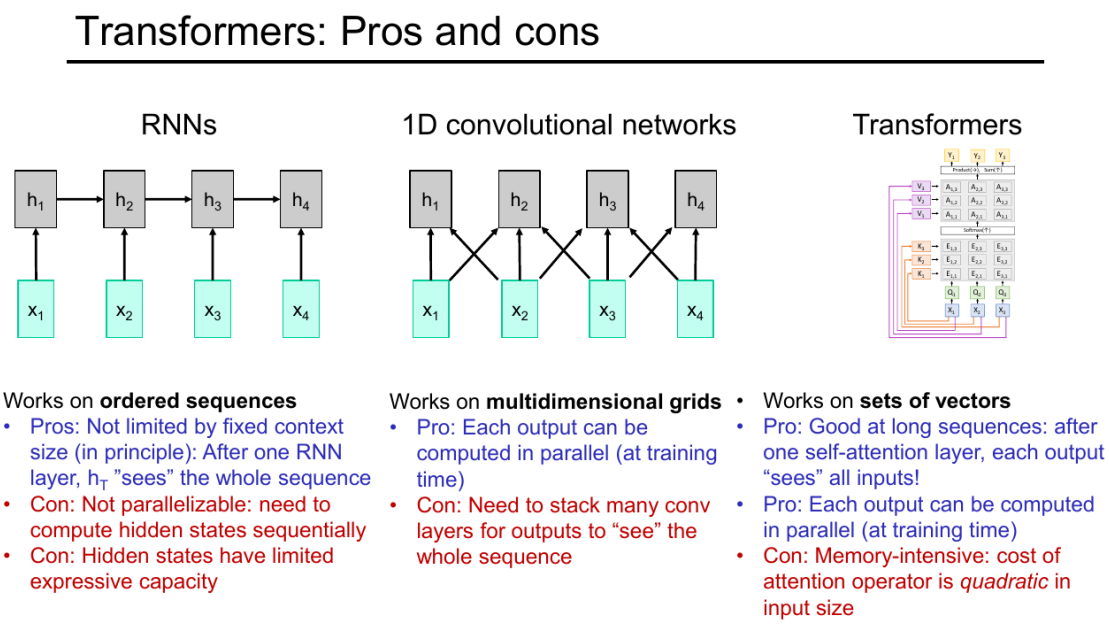

原课件第 22 页：用于图像建模的 Transformer

原页展示视觉 Transformer 分类与编码器–解码器图像建模示意图，标记图像块、位置嵌入、Transformer 编码器、MLP 分类头及输入、编码器、解码器和目标。

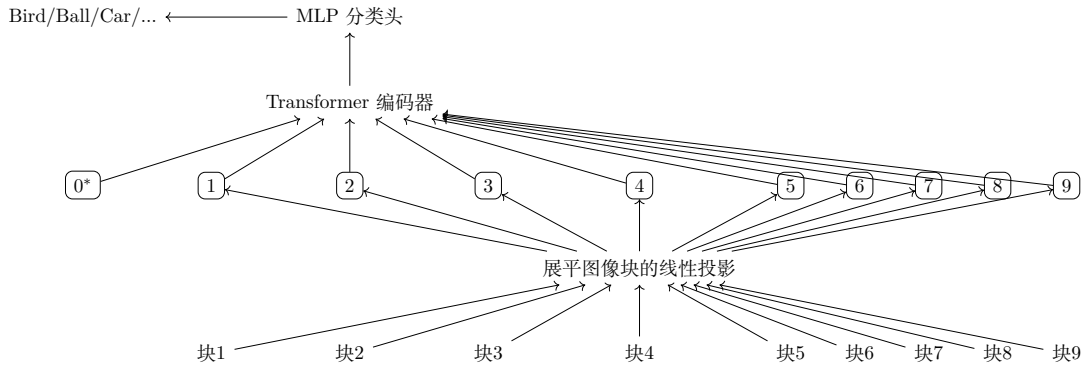

词元 0 为额外可学习的分类嵌入；块 1 至 9 依原图次序编号，各词元带图像块/位置嵌入。

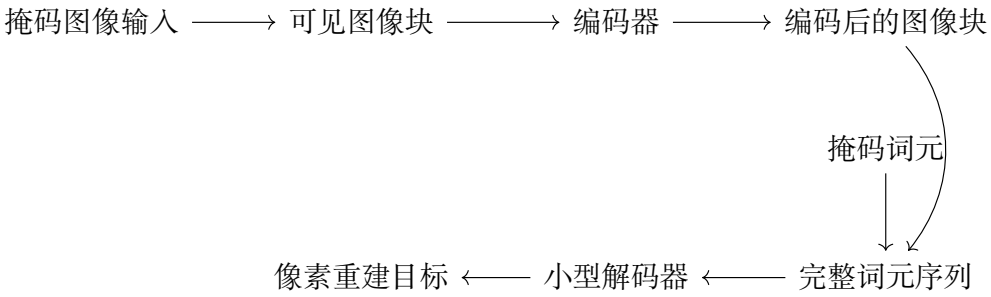

彩色图像块、掩码位置与重建像素依下方原图保留；此重建将同类词元画为带标签的分组，不为图像块添加不存在的数值。

原课件第 23 页：如何将 Transformer 用于视觉？

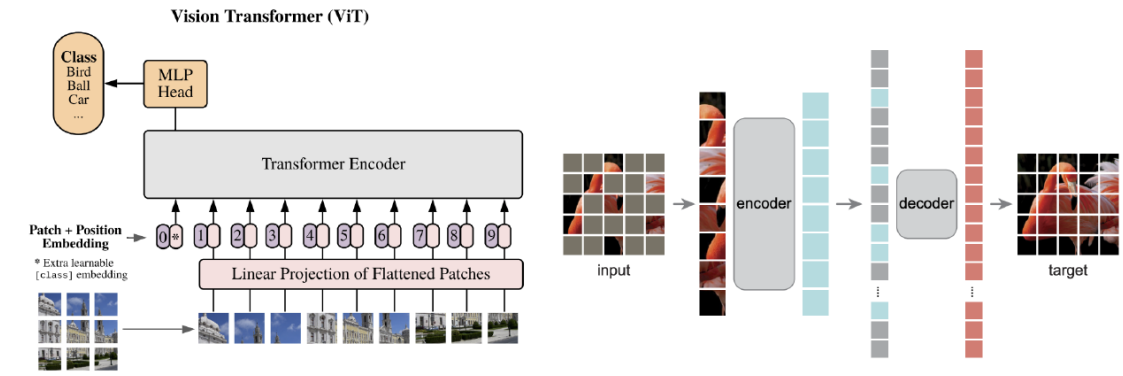

原页只有标题。

原课件第 24 页：思路 4——在图像块上使用 Transformer

原页展示一只猫的图像。来源：J. Johnson。

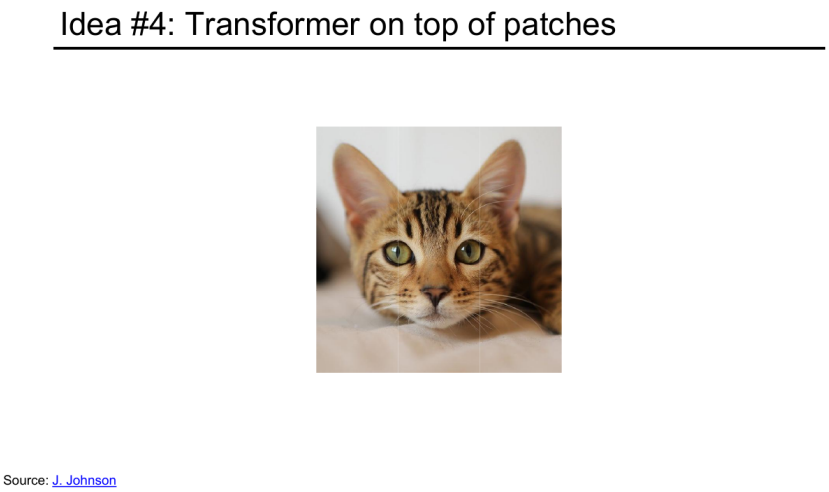

原课件第 25 页：思路 4（续）

原图将同一猫图像划分为图像块。来源：J. Johnson。

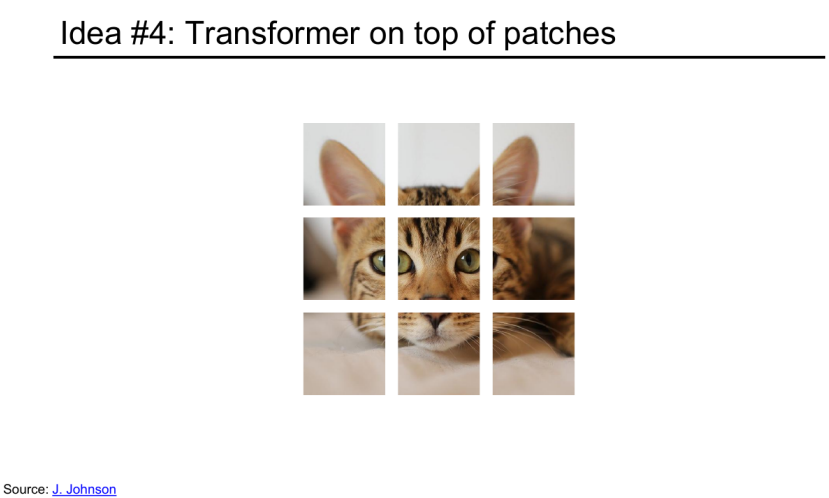

原课件第 26 页：视觉 Transformer（ViT）

把图像切分为图像块，线性投影后输入标准 Transformer 编码器。若每块为 14×14 像素，表示 224×224 图像需要 $16 \times 16 = 256$ 块。原图展示图像块、位置嵌入、编码器和分类头。来源：A. Dosovitskiy et al., *An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale*, ICLR 2021。

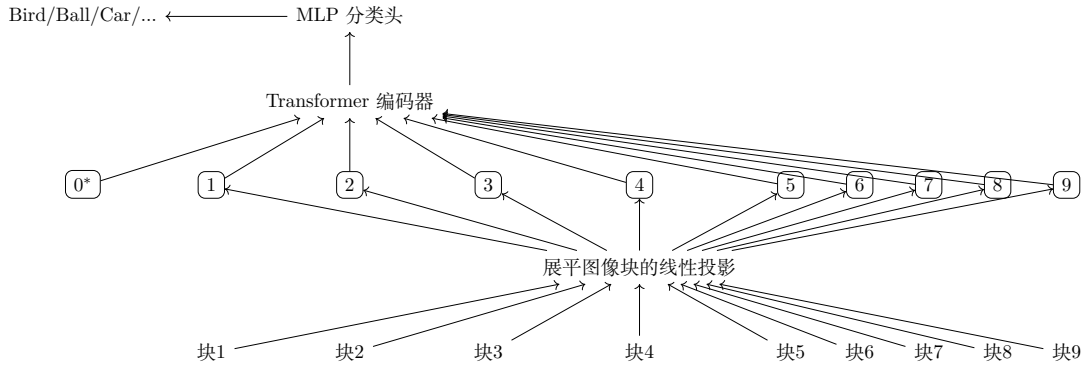

词元 0 为额外可学习的分类嵌入；块 1 至 9 依原图次序编号，各词元带图像块/位置嵌入。

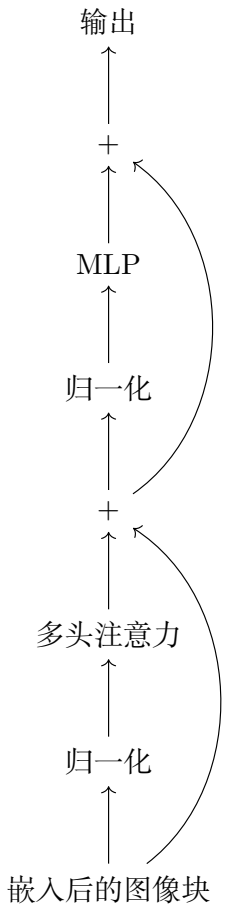

此编码器块重复 L 次。

Vision transformer (ViT)

- Split an image into patches, feed linearly projected patches into standard transformer encoder
  - With patches of 14x14 pixels, you need 16x16=256 patches to represent 224x224 images

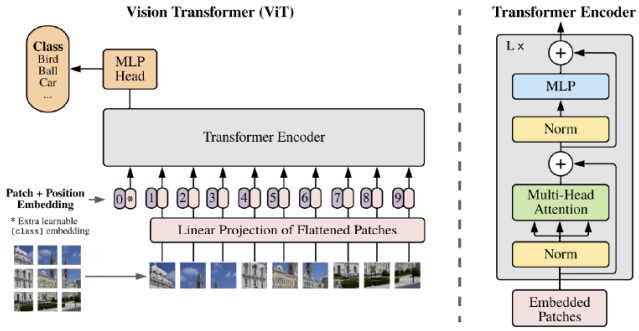

A. Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR 2021

原课件第 27 页：ViT 模型变体

沿用上一页的图像块说明。原表列出各变体的层数、隐层维数 D、MLP 大小、注意力头数和参数量：

模型	层数	D	MLP	头数	参数量
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

来源同上一页。

Vision transformer (ViT)

- Split an image into patches, feed linearly projected patches into standard transformer encoder
  - With patches of 14x14 pixels, you need 16x16=256 patches to represent 224x224 images

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

A. Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR 2021

原课件第 28 页：从图像块到视频世界模型

ViT 将图像切为图像块并称其为词元，这一做法并非图像所独有；视频模型预测下一个时空块。Genie、IRIS、STORM 是这种思路的不同版本。图中 a_t 是用户潜在动作，F 为动力学，E 为编码器，D 为解码器。来源：arXiv:2606.12783, Fig. 11。

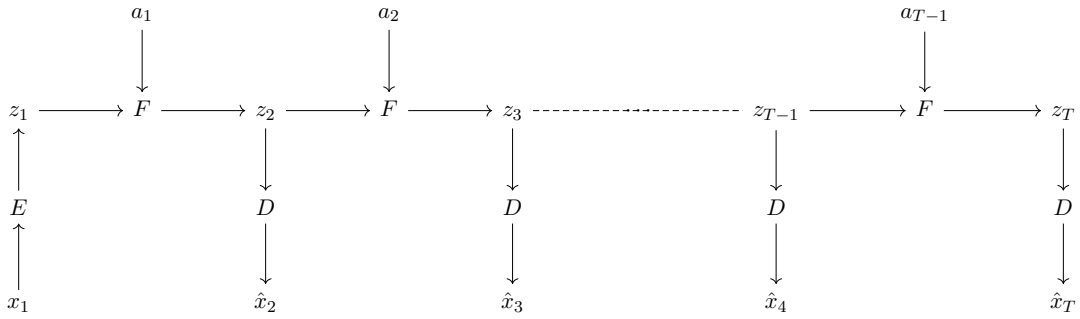

译注：源图在 z_{T-1} 下的解码输出标作 $\hat{x}_4$，此处照录，不静默改为 $\hat{x}_{T-1}$。

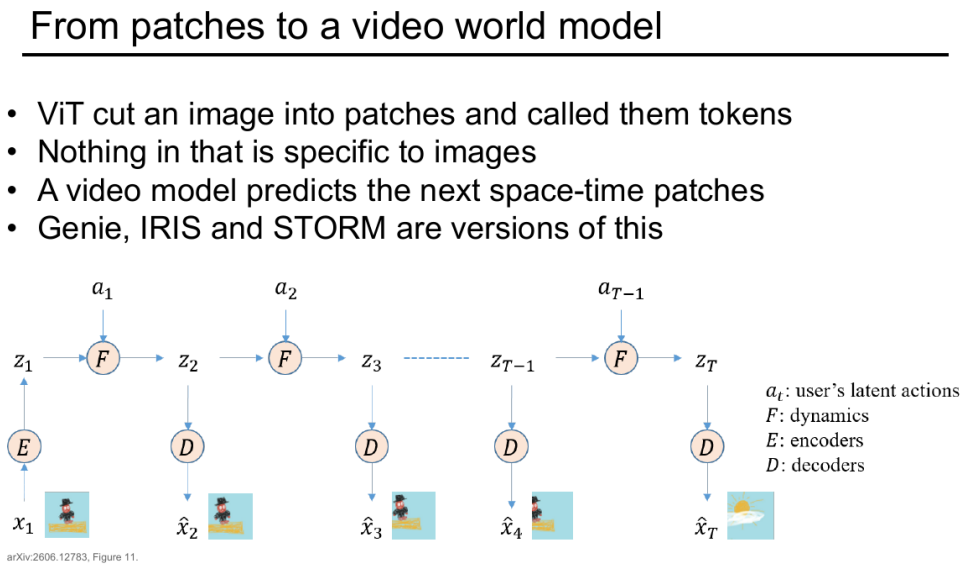

原课件第 29 页：提纲

接下来是无标签学习和强化学习与 Q 学习（马尔可夫决策过程、Bellman 方程、Q 学习、DQN）。

原课件第 30 页：自监督学习

原页以 M. C. Escher 的 *Drawing Hands*（1948）配图，来源经 A. Efros。

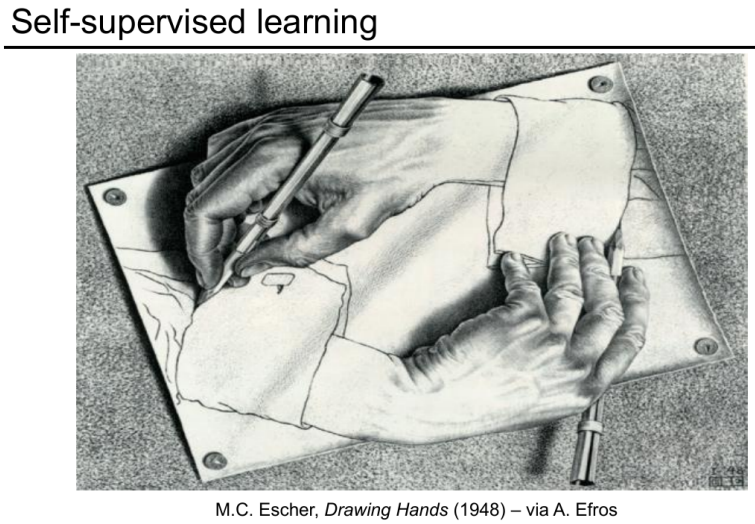

原课件第 31 页：动机

迁移学习从在大型多样化数据集上预训练的通用特征表示出发，将其适配到专门任务；挑战是克服对有监督预训练的依赖。原图显示有监督流程：图像经人工标注得到标签，(X, Y) 输入卷积网络得到学习表示，再用于迁移学习；红叉与“前置任务”标记强调改用前置任务。

X：图像 $\longrightarrow$ 人工标注 $\times$ $\longrightarrow$ Y：Cat/Dog/Hat $\times$ $\longrightarrow$ (X, Y)

前置任务

迁移学习 $\longleftarrow$ 学得表示 $\longleftarrow$ 卷积网络

原图用红色叉号划掉人工标注及标签路径，并在下方标出前置任务；不将叉号当作训练箭头。

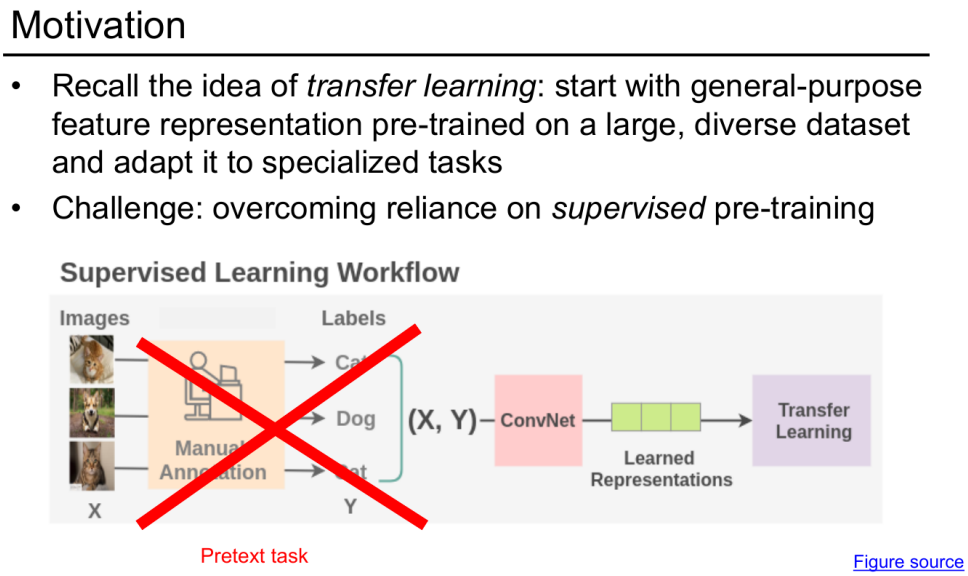

原课件第 32 页：无监督与自监督学习

无监督学习是任何无需标签的学习，包括聚类与量化、降维与流形学习、密度估计、学习采样。自监督学习是无监督学习的一种：学习器从数据中“构造”标签，然后求解有监督任务。

原课件第 33 页：掩码自编码器

图注译文：预训练时随机掩盖大部分图像块（如 75%）；编码器只处理少量可见块。掩码词元在编码器之后引入，编码图像块与掩码词元一起送入小型解码器，在像素空间重建原图。预训练之后丢弃解码器，对未受破坏的图像使用编码器，得到识别任务的表示。图示输入、编码器、解码器和目标。来源：K. He et al., *Masked Autoencoders Are Scalable Vision Learners*, CVPR 2022。

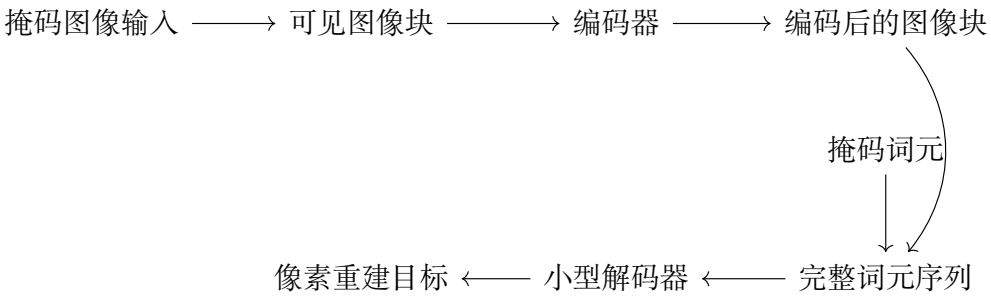

彩色图像块、掩码位置与重建像素依下方原图保留；此重建将同类词元画为带标签的分组，不为图像块添加不存在的数值。

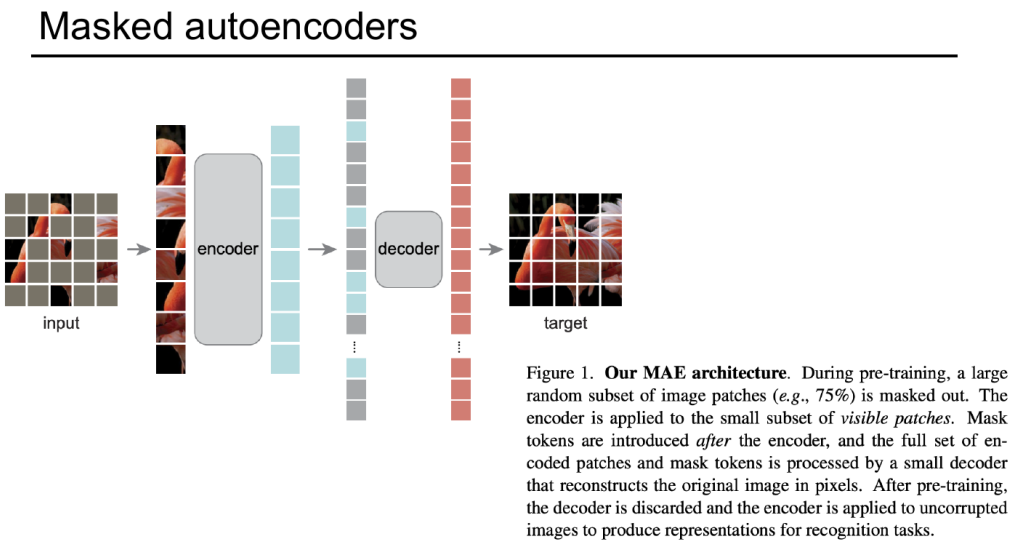

Figure 1. **Our MAE architecture**. During pre-training, a large random subset of image patches (*e.g.*, 75%) is masked out. The encoder is applied to the small subset of *visible patches*. Mask tokens are introduced *after* the encoder, and the full set of encoded patches and mask tokens is processed by a small decoder that reconstructs the original image in pixels. After pre-training, the decoder is discarded and the encoder is applied to uncorrupted images to produce representations for recognition tasks.

K. He et al. Masked autoencoders are scalable vision learners. CVPR 2022

原课件第 34 页：掩码自编码器重建示例

原图为 ImageNet 验证图像示例：每组三幅依次为掩码图像、MAE 重建、真实图像。掩码比例为 80%，196 块中仅保留 39 块；更多例子见原论文附录。原图脚注：可见块不计算损失，因而模型在这些块上的输出视觉质量较差；可以用可见块覆盖输出以改善画质，但作者有意不这样做，以更全面展示方法的行为。来源同上一页。

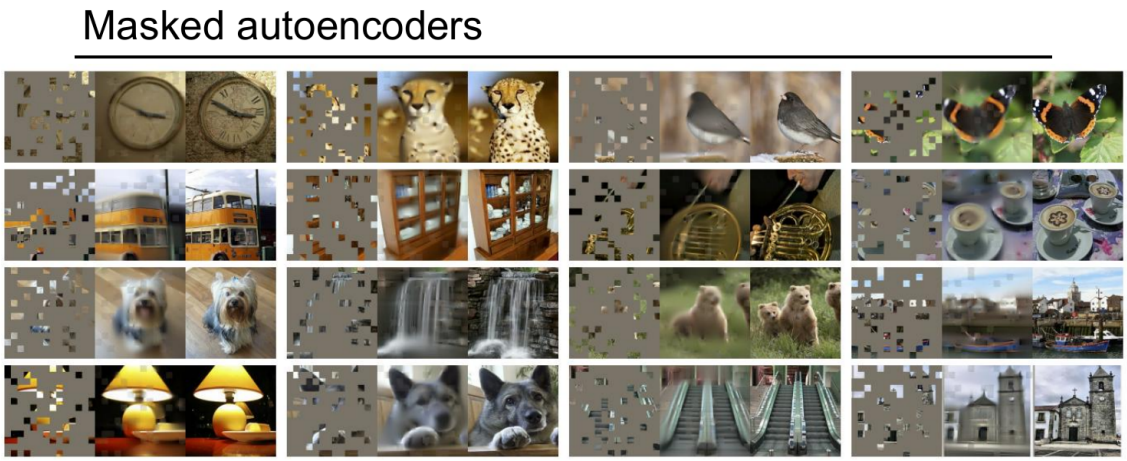

Figure 2. Example results on ImageNet *validation* images. For each triplet, we show the masked image (left), our MAE reconstruction† (middle), and the ground-truth (right). The masking ratio is 80%, leaving only 39 out of 196 patches. More examples are in the appendix. †*As no loss is computed on visible patches, the model output on visible patches is qualitatively worse. One can simply overlay the output with the visible patches to improve visual quality. We intentionally opt not to do this, so we can more comprehensively demonstrate the method's behavior.*

K. He et al. Masked autoencoders are scalable vision learners. CVPR 2022

原课件第 35 页：使用 Transformer 的自监督语言建模

1. 从互联网上下载大量文本。
2. 用合适的前置任务训练大型 Transformer。
3. 在目标自然语言处理任务上微调 Transformer（可选）。

原课件第 36 页：Transformer 的双向编码器表示（BERT）

原图对比预训练和微调：预训练使用无标签句子对、掩码语言模型及下一句预测；微调示例包括 MNLI、NER、SQuAD 和答案起止位置。来源：J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, EMNLP 2018。预训练：

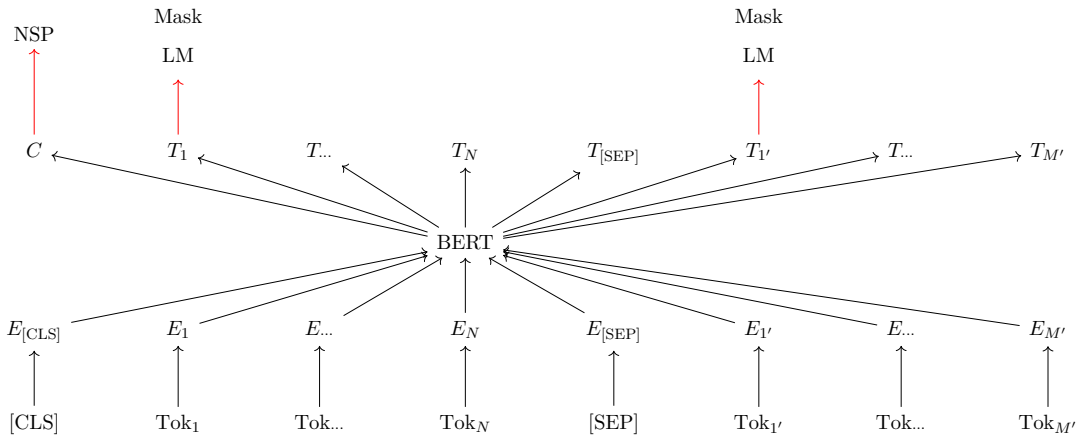

无标签句子 A/B 对；对句子 A、B 作掩码；C 用于 NSP，词元输出用于 Mask LM。微调：

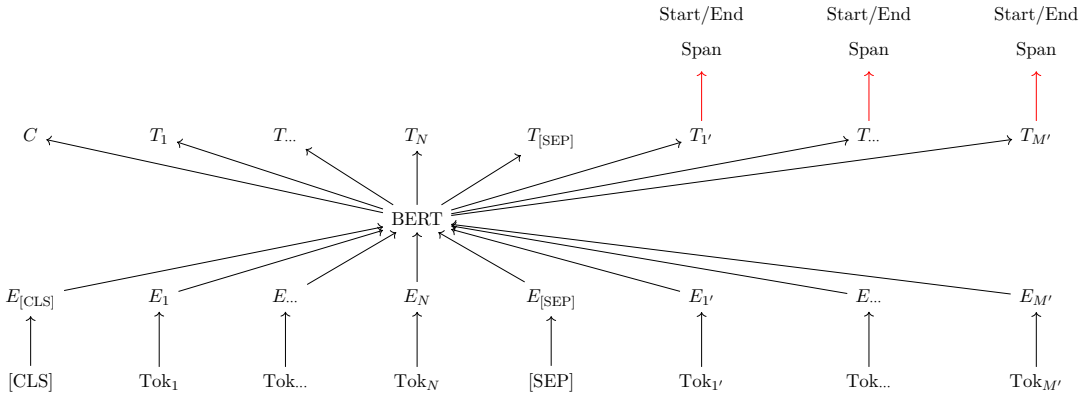

问答对中的 Question 与 Paragraph；示例下游任务包括 MNLI、NER、SQuAD，SQuAD 预测答案 Start/End Span。原图以点线箭头从预训练模型指向各微调任务；BERT 框内浅色神经节点作为模型内部示意，未赋予源图没有的层号。

预训练到各微调任务的点线迁移关系（内部神经元仍仅作示意）：

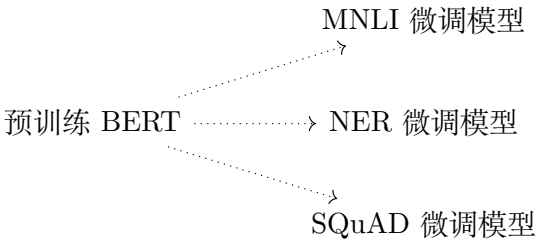

上方微调图展开原图最前层 SQuAD 的 Start/End Span 输出头；后叠的 MNLI、NER 模型在原图中未展开其任务头，故不补造。

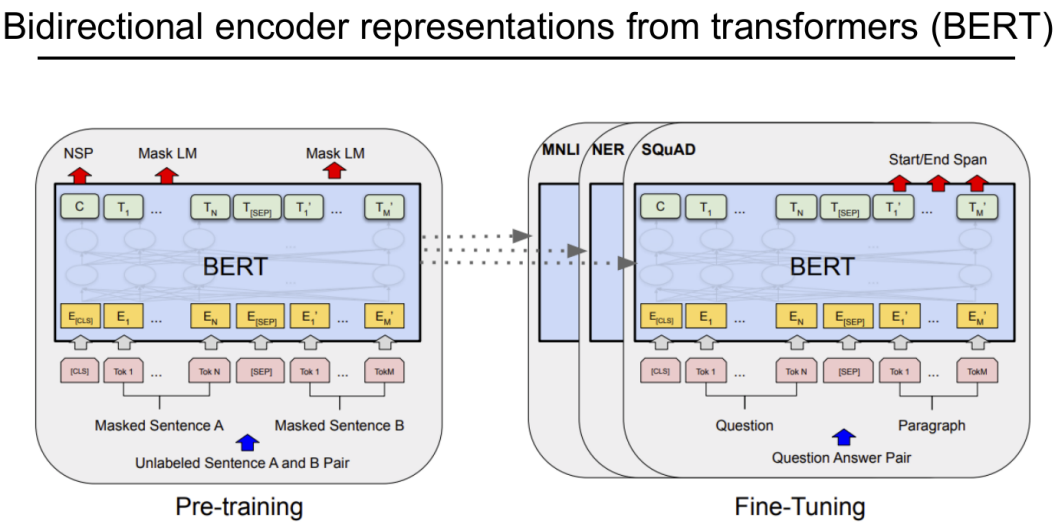

J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, EMNLP 2018

原课件第 37 页：BERT 前置任务

掩码语言模型（MLM）：随机掩盖输入句子中 15% 的词元，目标是利用双向上下文重建它们。图中输入示例为 *Let's stick to improvisation in this skit*，其中一个词元被掩盖后由 BERT 预测。

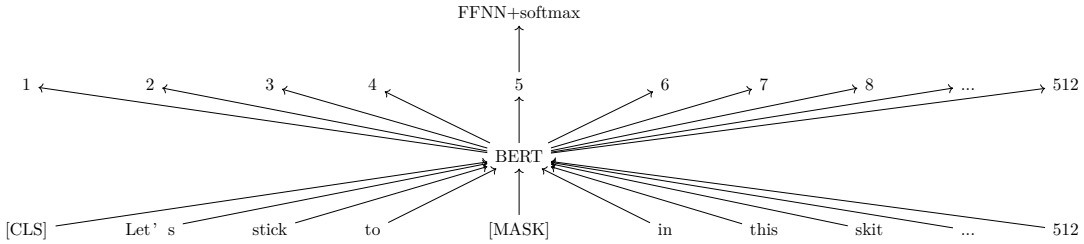

原句在第 5 个词元为 improvisation，此处以 [MASK] 替换；箭头突出对该位置的预测。

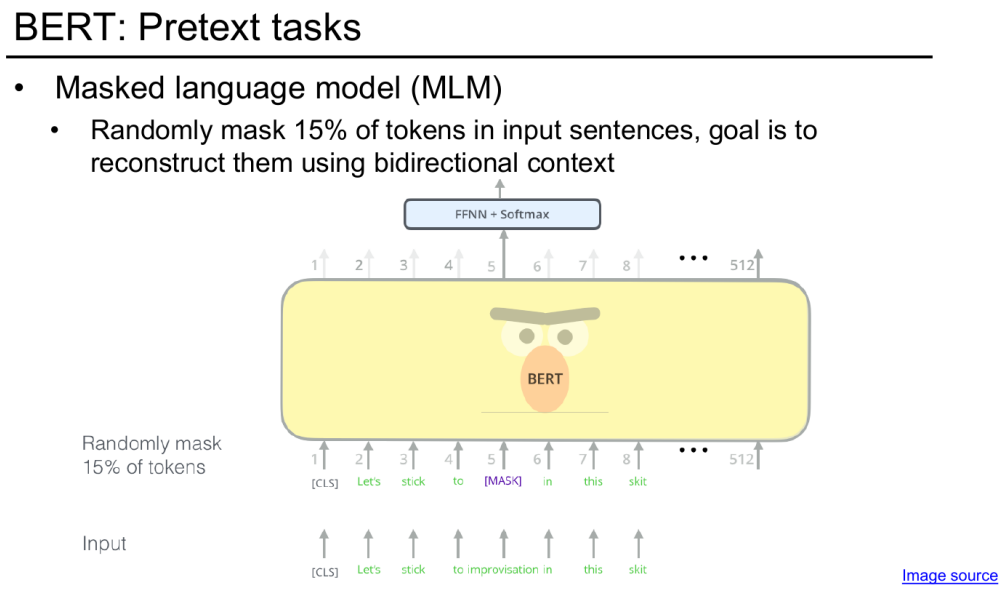

原课件第 38 页：非对比方法

从数据点的两个变换版本提取表示，鼓励两种表示相似。对比方法同时使用正对（相似）与负对（不相似）训练，主要挑战是采样负对；非对比方法仅用正例，主要挑战是避免退化解，即所有表示坍缩到同一常数输出。图示数据 $T(x), T'(x)$ 分别通过网络后计算相似度分数。来源：A. Efros。

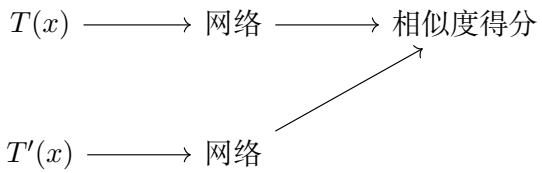

Non-contrastive methods

- Extract representations from two transformed versions of a data point, encourage these representations to be similar
  - **Contrastive methods**: train using both positive (similar) and negative (dissimilar) pairs
    - Key challenge: sampling of negative pairs
  - **Non-contrastive methods**: train with only positive examples
    - Key challenge: avoiding degenerate solutions (all representations collapsing to constant output value)

Source: A. Efros

原课件第 39 页：BYOL

在线分支像 SimCLR 一样使用投影，另加预测头以预测目标表示；目标分支使用动量编码器，不需要负例队列。

图注译文：BYOL 最小化 $q_\theta(z_\theta)$ 与 $\mathrm{sg}(z'_\xi)$ 之间的相似度损失；θ 是训练权重，ξ 是 θ 的指数移动平均，sg 表示停止梯度。训练结束时除 f_θ 外全部丢弃，并用 y_θ 作为图像表示。图中从输入图像经视图、表示、投影及预测得到在线和目标分支。来源：J.-B. Grill et al., *Bootstrap Your Own Latent: A New Approach to Self-Supervised Learning*, NeurIPS 2020。

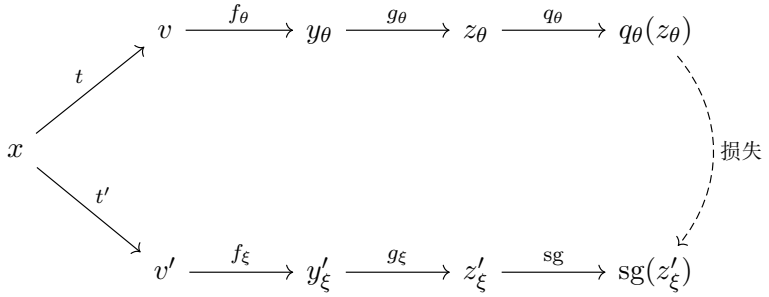

上支为 online，下支为 target；view、representation、projection、prediction 依次为视图、表示、投影、预测。

BYOL

- *Online branch* uses projection like SimCLR, plus an additional prediction head to predict the target representation
- *Target branch* uses momentum encoder, but there is no need for queue of negative examples

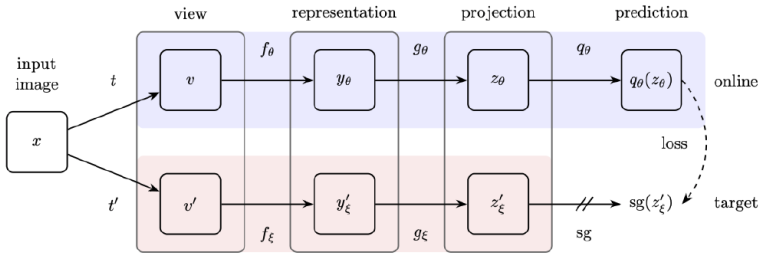

Figure 2: BYOL's architecture. BYOL minimizes a similarity loss between $q_\theta(z_\theta)$ and $\mathrm{sg}(z'_\xi)$, where θ are the trained weights, ξ are an exponential moving average of θ and sg means stop-gradient. At the end of training, everything but f_θ is discarded, and y_θ is used as the image representation.

J.-B. Grill et al. Bootstrap Your Own Latent A New Approach to Self-Supervised Learning. NeurIPS 2020

原课件第 40 页：SimSiam

它像 BYOL，但没有动量编码器；像 SimCLR，但没有负对。图注译文：同一图像的两个增强视图由相同的编码器 f（主干加投影 MLP）处理，再在一侧使用预测 MLP h，另一侧施加停止梯度；模型最大化两侧的相似度，既不使用负对，也不使用动量编码器。来源：X. Chen and K. He, *Exploring Simple Siamese Representation Learning*, CVPR 2021。

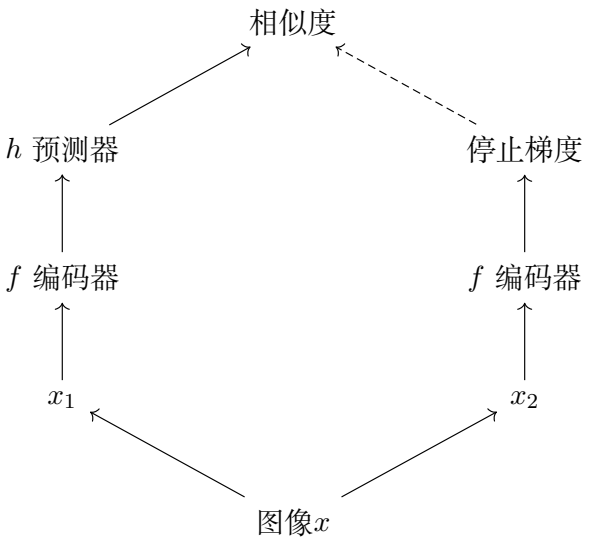

SimSiam

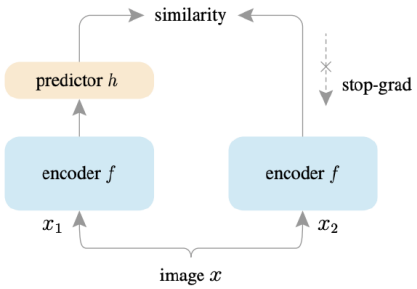

- Like BYOL, but without the momentum encoder
- Like SimCLR, but without the negative pairs

Figure 1. **SimSiam architecture**. Two augmented views of one image are processed by the same encoder network f (a backbone plus a projection MLP). Then a prediction MLP h is applied on one side, and a stop-gradient operation is applied on the other side. The model maximizes the similarity between both sides. It uses neither negative pairs nor a momentum encoder.

X. Chen and K. He. Exploring Simple Siamese Representation Learning. CVPR 2021

原课件第 41 页：DINO——无标签自蒸馏

图注译文：为简化起见，图中只有一对视图 (x_1, x_2)。输入图像的两种随机变换分别送入学生和教师网络；两网络架构相同、参数不同。教师输出用批次均值居中；每个网络输出 K 维特征，并沿特征维度用带温度的 softmax 归一化，以交叉熵损失衡量相似度。教师分支停止梯度，只有学生接收梯度；教师参数以学生参数的指数移动平均更新。来源：M. Caron et al., *Emerging Properties in Self-Supervised Vision Transformers*, ICCV 2021。

原页还给出无多重裁剪的 PyTorch 伪代码：`gs,gt` 为学生和教师，`C` 为中心，`tps,tpt` 为两者温度，`l,m` 为网络与中心的动量率。原代码如下；注释保留原文以便核对。

```
# gs, gt: student and teacher networks
# C: center (K)
# tps, tpt: student and teacher temperatures
# l, m: network and center momentum rates
gt.params = gs.params
for x in loader: # load a minibatch x with n samples
    x1, x2 = augment(x), augment(x) # random views

    s1, s2 = gs(x1), gs(x2) # student output n-by-K
    t1, t2 = gt(x1), gt(x2) # teacher output n-by-K

    loss = H(t1, s2)/2 + H(t2, s1)/2
    loss.backward() # back-propagate

    # student, teacher and center updates
    update(gs) # SGD
    gt.params = l*gt.params + (1-l)*gs.params
    C = m*C + (1-m)*cat([t1, t2]).mean(dim=0)
```

```
def H(t, s):
    t = t.detach() # stop gradient
    s = softmax(s / tps, dim=1)
    t = softmax((t - C) / tpt, dim=1) # center + sharpen
    return - (t * log(s)).sum(dim=1).mean()
```

图内注释依次说明加载小批量、生成随机视图、学生 / 教师输出形状为 $n \times K$、反向传播、更新学生 / 教师 / 中心、SGD、停止梯度和居中加锐化。原页左侧图的节点与更新方向另以可编辑图保留；sg 标记教师输出的停止梯度，ema 标记参数指数移动平均更新：

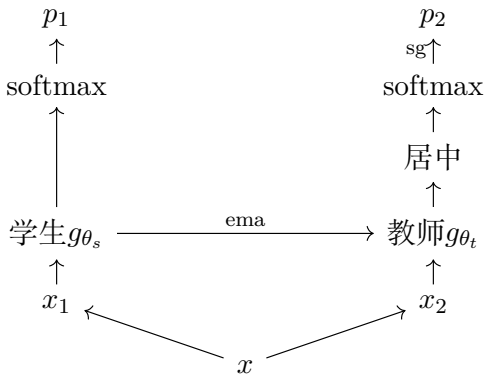

图中损失：　$-\,p_2 \log p_1$.

DINO: Self-distillation with no labels

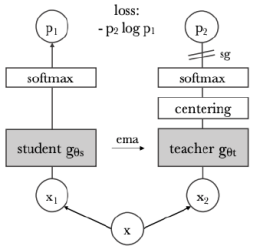

Figure 2: **Self-distillation with no labels.** We illustrate DINO in the case of one single pair of views (x_1, x_2) for simplicity. The model passes two different random transformations of an input image to the student and teacher networks. Both networks have the same architecture but different parameters. The output of the teacher network is centered with a mean computed over the batch. Each networks outputs a K dimensional feature that is normalized with a temperature softmax over the feature dimension. Their similarity is then measured with a cross-entropy loss. We apply a stop-gradient (sg) operator on the teacher to propagate gradients only through the student. The teacher parameters are updated with an exponential moving average (ema) of the student parameters.

Algorithm 1 DINO PyTorch pseudocode w/o multi-crop.

```
# gs, gt: student and teacher networks
# C: center (K)
# tps, tpt: student and teacher temperatures
# l, m: network and center momentum rates
gt.params = gs.params
for x in loader: # load a minibatch x with n samples
    x1, x2 = augment(x), augment(x) # random views

    s1, s2 = gs(x1), gs(x2) # student output n-by-K
    t1, t2 = gt(x1), gt(x2) # teacher output n-by-K

    loss = H(t1, s2)/2 + H(t2, s1)/2
    loss.backward() # back-propagate

    # student, teacher and center updates
    update(gs) # SGD
    gt.params = l*gt.params + (1-l)*gs.params
    C = m*C + (1-m)*cat([t1, t2]).mean(dim=0)

def H(t, s):
    t = t.detach() # stop gradient
    s = softmax(s / tps, dim=1)
    t = softmax((t - C) / tpt, dim=1) # center + sharpen
    return - (t * log(s)).sum(dim=1).mean()
```

M. Caron et al. Emerging Properties in Self-Supervised Vision Transformers. ICCV 2021

原课件第 42 页：在表示空间中预测

BYOL、SimSiam 和 DINO 在特征空间预测，不重建像素，也不使用负对；JEPA 将此类预测扩展到跨时间。原图中 s_x, s_y 分别是 x, y 的表示，$\hat{s}_y$ 是 y 的预测，z 是潜变量，E 是编码器，P 是预测器；图还标有上下文、目标、位置嵌入及损失 $\mathcal{L}$。来源：arXiv:2606.12783, Fig. 13。

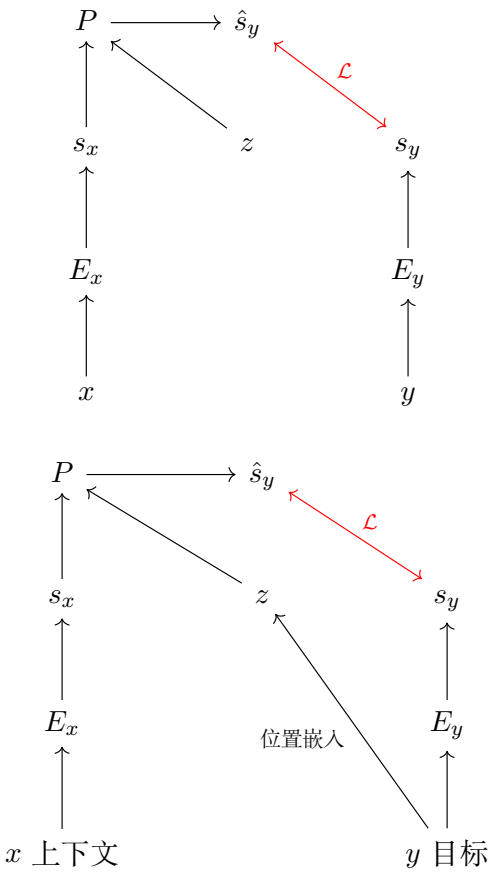

原页的两幅图像实例共用上述上下文/目标连接；两实例的目标掩码不同，原图完整保留于下方。s_x, s_y 为表示，$\hat{s}_y$ 为预测，z 为潜变量。

Predicting in representation space

- BYOL, SimSiam and DINO predict in feature space
- No pixels reconstructed, no negative pairs
- JEPA moves that prediction across time

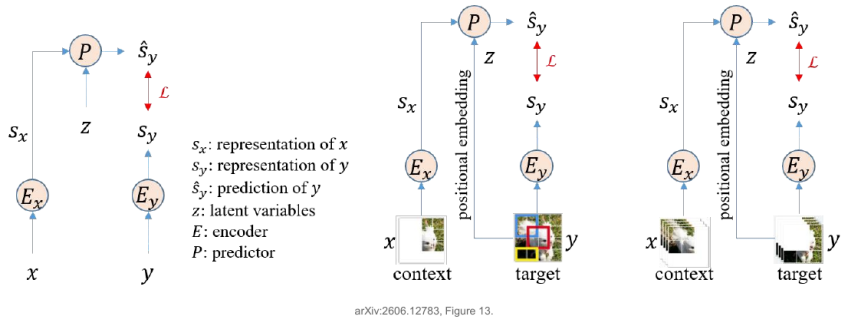

原课件第 43 页：提纲

接下来介绍强化学习与 Q 学习，包括马尔可夫决策过程、Bellman 方程、Q 学习和 DQN。

原课件第 44 页：深度强化学习简介

原页配有实验动物与装置的照片。

Introduction to deep reinforcement learning

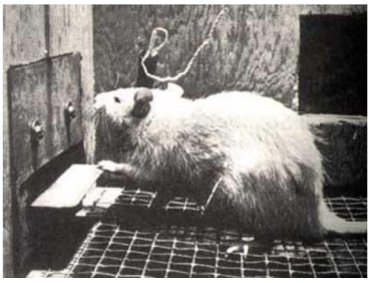

原课件第 45 页：强化学习

设定：智能体可以采取影响环境状态的动作，并偶尔观察到依赖于状态的奖励。目标是学习状态到动作的策略，使随时间的期望奖励最大。原图见第 1 份第 47 页。

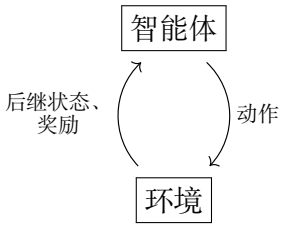

原课件第 46 页：深度强化学习应用示例

应用之一是玩游戏。图中标出状态 s_t、动作 a_t 和奖励 r_t。来源：V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller, *Human-level control through deep reinforcement learning*, Nature 2015。

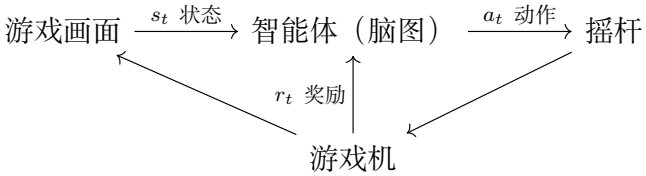

Example applications of deep RL

- Playing games

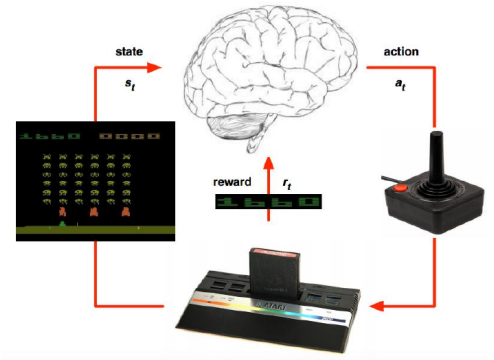

V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller,
Human-level control through deep reinforcement learning, *Nature* 2015

原课件第 47 页：形式化——马尔可夫决策过程

组成包括状态 s（从初始状态 s_0 开始）、动作 a、转移模型 $P(s' \mid s, a)$ 和奖励函数 $r(s)$。马尔可夫假设指从 s 到 s' 的概率只依赖 s, a，不依赖其他历史动作或状态。策略 $\pi(s)$ 是智能体在给定状态下采取的动作，是一个 MDP 的“解”。

原课件第 48 页：MDP 示例——网格世界

原图中有起点、障碍、+1 与 −1 终止格；每个非终止状态的奖励为 $r(s) = -0.04$。转移模型图示目标方向概率为 0.8，两个侧向结果各为 0.1。来源：P. Abbeel and D. Klein。

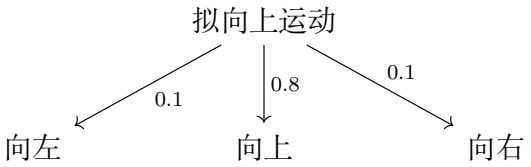

Example MDP: Grid world

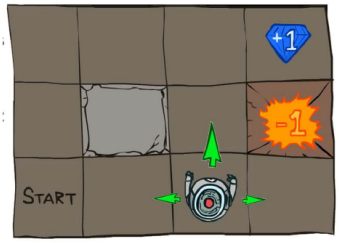

$r(s) = -0.04$ for every non-terminal state

Transition model:

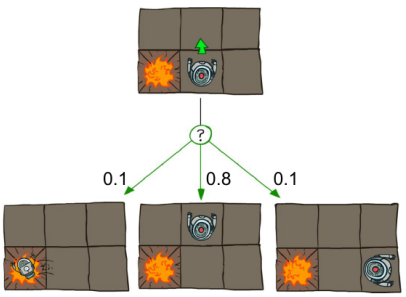

Source: P. Abbeel and D. Klein

原课件第 49 页：网格世界的策略

目标是寻找最优策略；图中箭头表示各网格中的动作。来源：P. Abbeel and D. Klein。

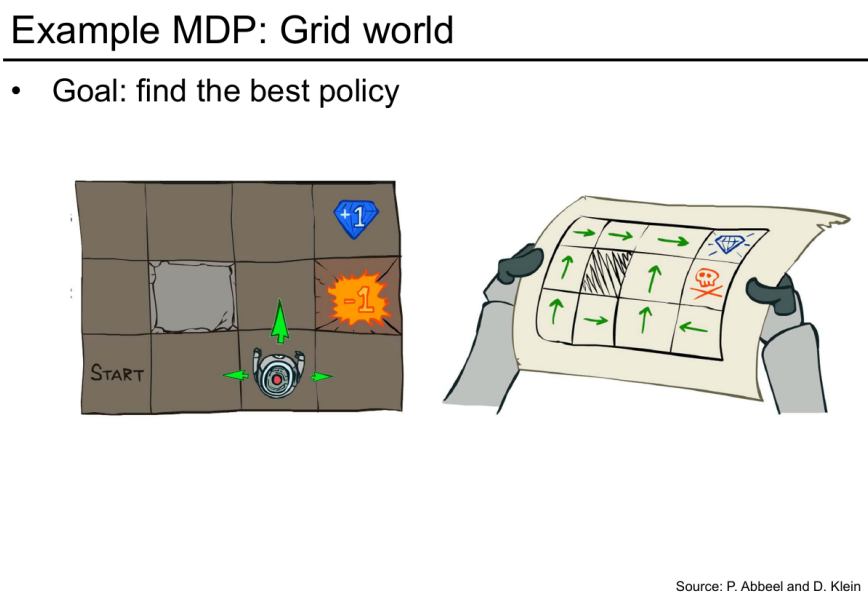

原课件第 50 页：不同奖励下的最优策略

原图分别展示 $R(s) < -1.6284$、$-0.4278 < R(s) < -0.0850$、$-0.0221 < R(s) < 0$、$R(s) > 0$ 时的策略箭头。此处沿用图中大写 R，标题则写 $r(s)$；图中只列出这些区间，不推断其间未列区间的策略。

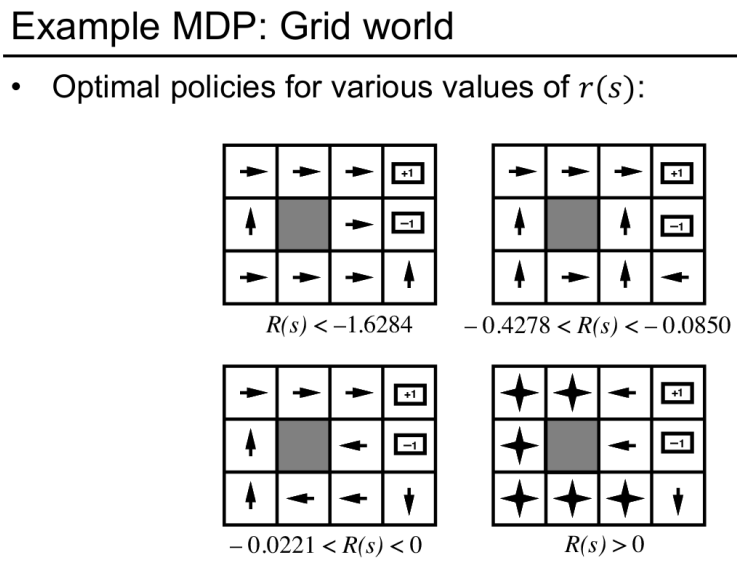

原课件第 51 页：强化学习循环

从状态 s 出发，采取策略 $\pi(s)$ 决定的动作 a；环境依据 $P(s' \mid s, a)$ 选择下一状态 s'；观察 s' 和奖励 $r(s')$，更新策略。

对比随机梯度下降（SGD）：从数据分布独立同分布采样输入 x_i，用参数 w 的模型预测输出 y，观察目标 y_i 与损失 $l(w, x_i, y_i)$，然后更新

$$w \leftarrow w - \eta \nabla l(w, x_i, y_i).$$

原课件第 52 页：强化学习与监督学习

强化学习中，智能体动作影响环境并参与决定下一次观测；奖励可能稀疏，且相对于模型参数不可微。监督学习中，下一输入不依赖之前输入或智能体预测；每一步都有监督信号，损失相对于模型参数可微。这些是原页的概括性表述，具体设定可能不同。

原课件第 53 页：求解 MDP

再次列出状态 s、初始状态 s_0、动作 a、转移模型 $P(s' \mid s, a)$、马尔可夫假设与奖励 $r(s)$。策略 $\pi(s)$ 给出每个状态的动作，是 MDP 的“解”；问题是如何找到这个解。

原课件第 54 页：状态序列的累积奖励

假设从 s_0 出发遵循策略 π，得到序列或轨迹 $\tau = (s_0, s_1, s_2, \ldots)$。如何定义轨迹的累积奖励？原页指出，逐状态奖励之和不按序列长度归一化，甚至可能无穷；提出用折扣因子 γ、$0 < \gamma \leq 1$ 对奖励求和。图中当前、下一步、两步后的价值分别标为 $1, \gamma, \gamma^2$。来源：P. Abbeel and D. Klein。$\gamma = 1$ 时无限时域求和的收敛仍需额外条件，原页未列出。

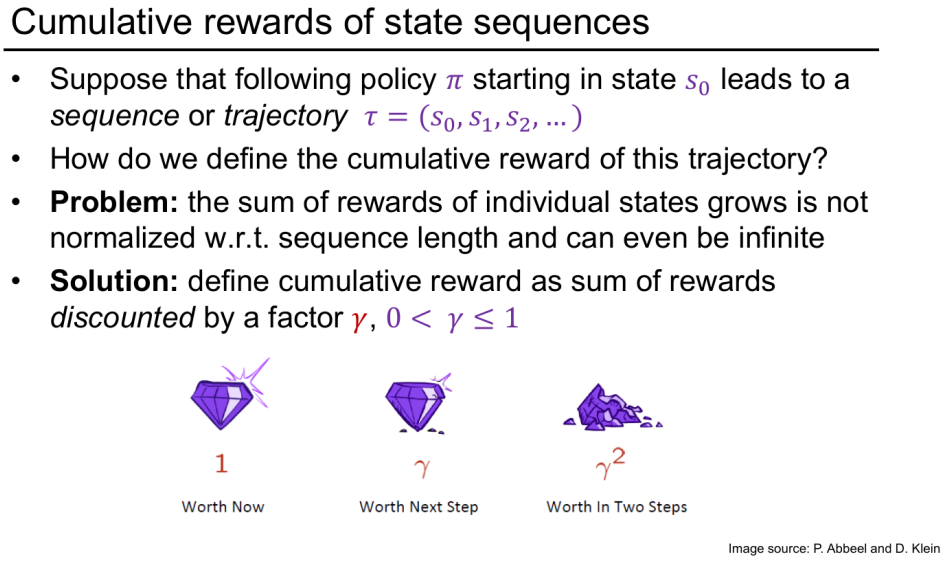

第 4 份课件：价值函数与深度 Q 学习

原课件第 1 页：封面

CS 6804：世界模型；Chris Thomas，Virginia Tech 计算机科学系，2026 年秋季。许多幻灯片改编自 Graumann、Kovashka、Lazebnik、Fouhey、Lowe、Seitz、Batra、Forsyth、Fei-Fei Li 和 Hoiem 的材料。

原课件第 2 页：求解 MDP

状态 s 从 s_0 开始；给定动作 a，转移模型 $P(s' \mid s, a)$ 依马尔可夫假设只依赖当前状态和动作；奖励为 $r(s)$。策略 $\pi(s)$ 指每个状态采取的动作，是 MDP 的“解”；如何找到它？

原课件第 3 页：状态序列的累积奖励

策略 π 从 s_0 出发产生轨迹 $\tau = (s_0, s_1, \ldots)$。逐状态奖励之和不按序列长度归一化，还可能无穷；原页提出以 $0 < \gamma \leq 1$ 折扣求和。原图及 $\gamma = 1$ 收敛限制见第 3 份第 54 页。

原课件第 4 页：折扣

原页给出轨迹的折扣累积奖励及递推：

$$r(s_0, s_1, s_2, \ldots) = r(s_0) + \gamma r(s_1) + \gamma^2 r(s_2) + \cdots = \sum_{t \geq 0} \gamma^t r(s_t),$$

$$r(s_0, s_1, s_2, \ldots) = r(s_0) + \gamma r(s_1, s_2, s_3, \ldots).$$

课件称总和以 $r_{\max}/(1-\gamma)$ 为界，括号中假设 $0 < \gamma \leq 1$，并称折扣有助于算法收敛。这里保留原文；当 $\gamma = 1$ 时该分母为零，而无限和的有界性还需要适当条件。

原课件第 5 页：价值函数

状态 s 关于策略 π 的价值函数是从 s 开始遵循该策略的期望累积奖励：

$$V^\pi(s) = \mathbb{E}_\tau[r(\tau) \mid s_0 = s, \pi], \qquad s_{t+1} \sim P(\cdot \mid s_t, a_t), \qquad V^*(s) = \max_\pi V^\pi(s).$$

其中轨迹从 s 开始，动作由 π 给出，后继状态按转移模型抽取；最优价值是遵循最佳策略可达到的价值。

原课件第 6 页：最优策略

如何用最优状态价值表示最优策略？原图从状态 s 指向多个可能的动作，提出应选择哪个动作。

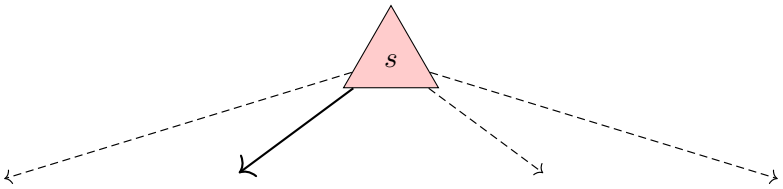

The optimal policy

- How do we express the optimal policy in terms of optimal state values?

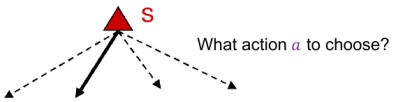

原课件第 7 页：最优策略（续）

原图进一步表示智能体选择动作 a，进入标记为 (s, a) 的节点。

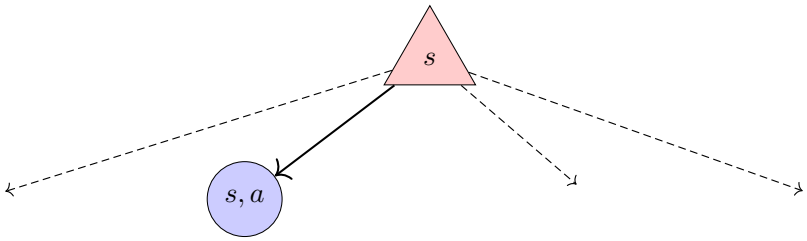

The optimal policy

- How do we express the optimal policy in terms of optimal state values?

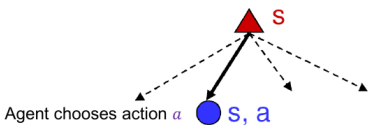

原课件第 8 页：最优策略（续）

选择使期望未来累积价值最大的动作：

$$\pi^*(s) = \arg\max_a \mathbb{E}_{s'\sim P(\cdot|s,a)} V^*(s'),$$
$$\mathbb{E}_{s'\sim P(\cdot|s,a)} V^*(s') = \sum_{s'} P(s' \mid s,a) V^*(s').$$

图中智能体选动作 a，环境再按 $P(\cdot \mid s,a)$ 选 s'，后继状态的价值为 $V^*(s')$。

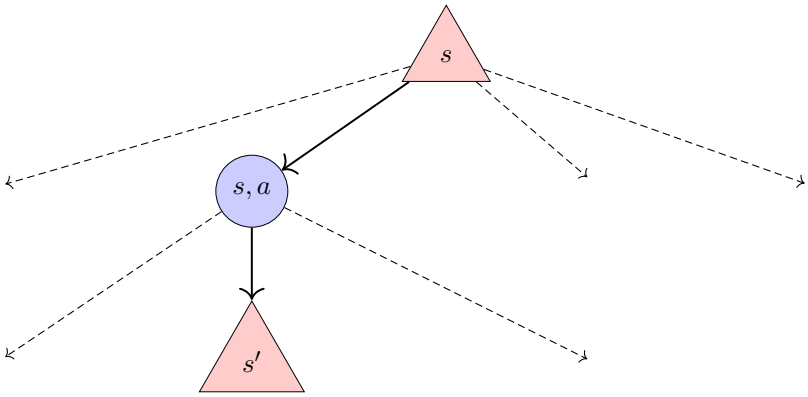

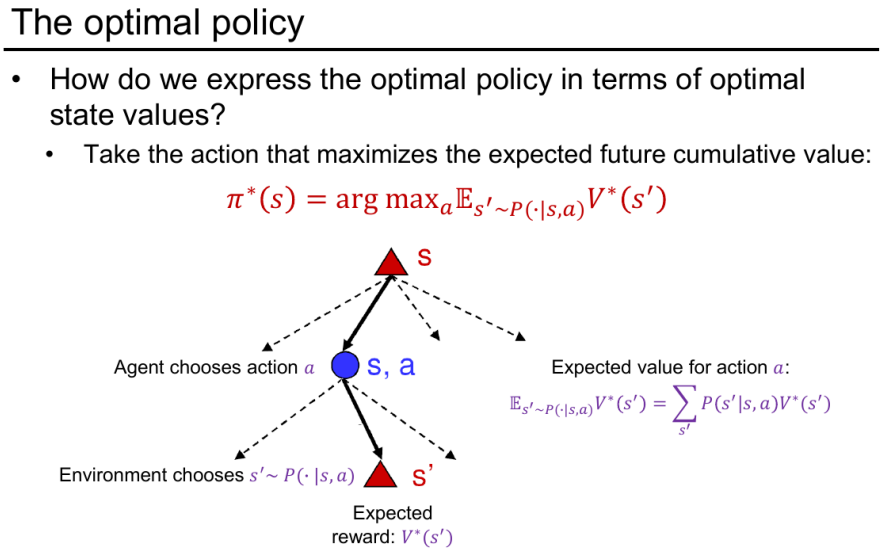

原课件第 9 页：Bellman 方程

$$V^*(s) = r(s) + \gamma \max_a \mathbb{E}_{s'\sim P(\cdot|s,a)} V^*(s').$$

第一项是当前状态奖励，第二项是此后遵循最优策略时的期望未来累积价值。图示智能体收到 $r(s)$、选择动作，环境选择后继状态，并重复上一页最优策略式。

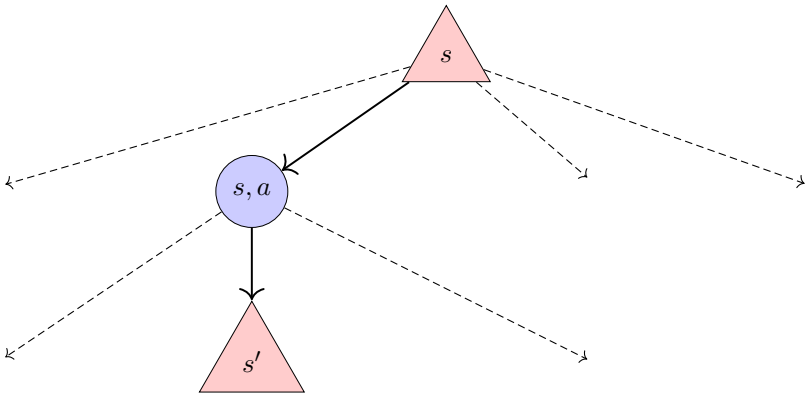

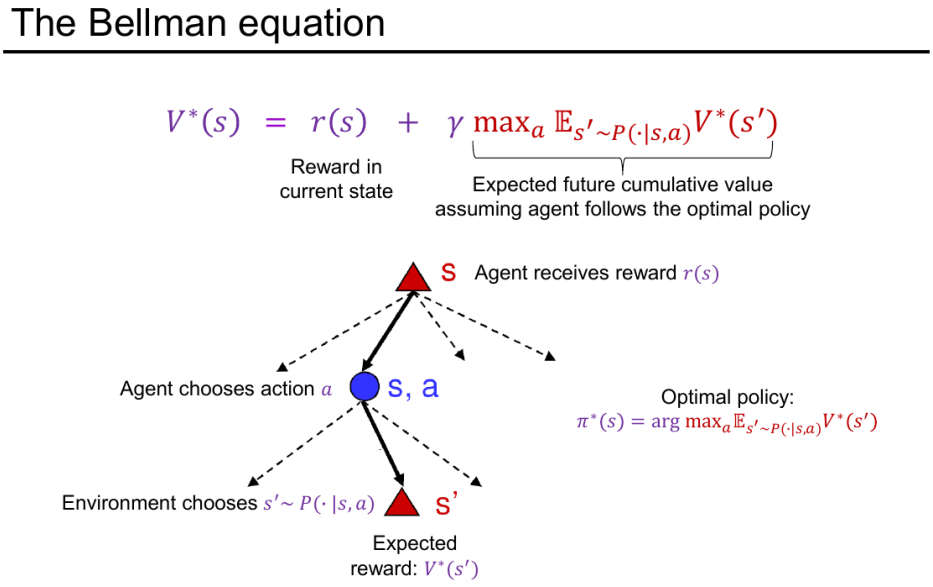

原课件第 10 页：Bellman 方程（续）

上述方程是相继状态最优价值之间的递推关系。

原课件第 11 页：Q 学习

使用状态价值选择动作需要知道转移模型：

$$\pi^*(s) = \arg\max_a \mathbb{E}_{s' \sim P(\cdot|s,a)} V^*(s') = \arg\max_a \sum_{s'} P(s' \mid s, a) V^*(s').$$

更方便的做法是定义状态–动作对的价值：

$$Q^\pi(s,a) = \mathbb{E}_\tau[r(\tau) \mid s_0 = s, a_0 = a, \pi], \qquad \pi^*(s) = \arg\max_a Q^*(s,a).$$

原课件第 12 页：Q 值函数示例

原图对网格世界各状态和方向以数值及颜色展示 Q 值。按左图横坐标、纵坐标记格点，右图各格三角区的上、左、右、下位置数值如下（照图抄录；终止格单独列出）：

格点	上	左	右	下
$(1,3)$	0.59	0.58	0.70	0.54
$(2,3)$	0.66	0.60	0.78	0.66
$(3,3)$	0.64	0.68	0.88	0.58
$(1,2)$	0.61	0.52	0.52	0.49
$(3,2)$	-0.51	0.42	-0.43	0.15
$(1,1)$	0.54	0.45	0.43	0.47
$(2,1)$	0.40	0.48	0.33	0.42
$(3,1)$	0.31	0.39	0.28	0.27
$(4,1)$	-0.89	0.28	-0.38	0.11

$(2,2)$ 为障碍，终止格 $(4,3)$、$(4,2)$ 分别显示 1.00、-1.00；起点为 $(1,1)$。

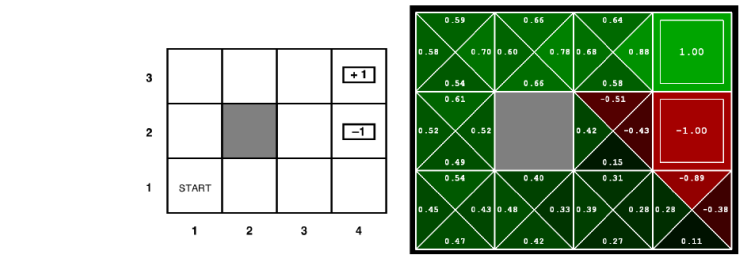

原课件第 13 页：Q 值的 Bellman 方程

$$
\begin{aligned}
V^*(s) &= \max_a Q^*(s,a), \\
V^*(s) &= r(s) + \gamma \max_a \mathbb{E}_{s' \sim P(\cdot|s,a)} V^*(s'), \\
Q^*(s,a) &= r(s) + \gamma \mathbb{E}_{s' \sim P(\cdot|s,a)} \max_{a'} Q^*(s',a') \\
&= \mathbb{E}_{s' \sim P(\cdot|s,a)} \left[r(s) + \gamma \max_{a'} Q^*(s',a') \right].
\end{aligned}
$$

原课件第 14 页：深度 Q 学习

原页重复 Q 值关系，并提出用神经网络估计：

$$Q^*(s,a) = \mathbb{E}_{s'\sim P(\cdot|s,a)}[r(s) + \gamma \max_{a'} Q^*(s',a') \mid s,a],$$

$$Q^*(s,a) \approx Q_w(s,a).$$

原图中状态 s 输入权重为 w 的网络，输出不同动作的 Q 值。来源：V. Mnih et al., *Human-level control through deep reinforcement learning*, Nature 2015。

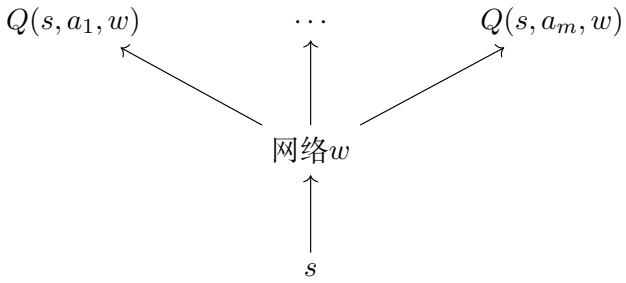

Deep Q-learning

$Q^*(s,a) = \mathbb{E}_{s'\sim P(\cdot|s,a)}\,[r(s) + \gamma \max_{a'} Q^*(s',a')|s,a]$

- **Idea 1**: estimate Q-values using a neural network:

$Q^*(s,a) \approx Q_w(s,a)$

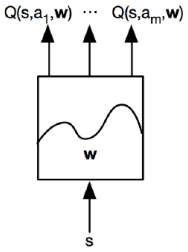

V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller, Human-level control through deep reinforcement learning, *Nature* 2015

原课件第 15 页：深度 Q 学习（续）

思路一：用神经网络 $Q_w(s,a)$ 估计 $Q^*(s,a)$。思路二：不对后继状态求期望，而以单个转移 (s,a,s') 更新估计，使之更接近目标 $r(s)+\gamma\max_{a'} Q_w(s',a')$。思路三：为避免训练不稳定，用网络的另一个快照 Q_{target} 计算目标值。

原课件第 16 页：深度 Q 学习更新

给定转移 (s, a, s')，原页给出目标、损失及称作“梯度更新”的表达式：

$$
\begin{aligned}
y_{\text{target}}(s, a, s') &= r(s) + \gamma \max_{a'} Q_{\text{target}}(s', a'), \\
L(w) &= \mathbb{E}_{s,a,s'} \big(y_{\text{target}}(s, a, s') - Q_w(s, a)\big)^2, \\
\nabla_w L(w) &= \mathbb{E}_{s,a,s'} \left[(y_{\text{target}}(s, a, s') - Q_w(s, a)) \nabla_w Q_w(s, a)\right] \\
&= \mathbb{E}_{s,a,s'} \left[(r(s) + \gamma \max_{a'} Q_{\text{target}}(s', a') - Q_w(s, a)) \nabla_w Q_w(s, a)\right].
\end{aligned}
$$

通过行为分布选动作并使用经验回放缓冲区采样转移。原页最后两式按原样转录；若目标对 w 固定，它们与所写平方损失的通常梯度相差负号和因子 2，故作为源文疑点记录，不静默修正。

原课件第 17 页：深度 Q 学习的实践问题

训练容易不稳定：与监督学习不同，目标本身在变化；连续经验相关且依赖策略；参数略变可能使策略迅速变化，从而使数据分布剧变。解决方法包括冻结目标 Q 网络（或使用指数移动平均）及经验回放。

原课件第 18 页：深度 Q 学习总结

每个时间步按 ϵ-贪心策略选动作 a_t，将 $(s_t, a_t, r_{t+1}, s_{t+1})$ 存入回放缓冲区；随机抽取小批量，在下列损失上执行梯度下降，每 C 步更新目标网络：

$$
L(w) = \mathbb{E}_{s,a,s'} \left[\big(r(s) + \gamma \max_{a'} Q_{\text{target}}(s', a') - Q_w(s, a)\big)^2\right].
$$

回放表原有示例按顺序为：

$$
\begin{array}{c}
(s_1, a_1, r_2, s_2) \\
\hline
(s_2, a_2, r_3, s_3) \\
\hline
(s_3, a_3, r_4, s_4) \\
\hline
\cdots \\
\hline
(s_t, a_t, r_{t+1}, s_{t+1})
\end{array}
$$

译注：回放元组用 r_{t+1}，本页损失沿用 $r(s)$；两种奖励索引按原课件分别保留，不默认为完全相同的时序约定。

Deep Q-learning: Summary

- At each time step:
  - Take action a_t according to *epsilon-greedy policy*
  - Store experience $(s_t, a_t, r_{t+1}, s_{t+1})$ in *replay memory buffer*

s_1, a_1, r_2, s_2
s_2, a_2, r_3, s_3
s_3, a_3, r_4, s_4
…
$s_t, a_t, r_{t+1}, s_{t+1}$

  - Randomly sample *mini-batch* of experiences from the buffer
  - Perform gradient descent step on loss:
    $L(w) = \mathbb{E}_{s,a,s'}\left[(r(s) + \gamma \max_{a'} Q_{\text{target}}(s', a') - Q_w(s, a))^2\right]$
  - Update target network every C steps

原课件第 19 页：Atari 中的深度 Q 学习

原图展示游戏状态、动作和奖励的交互。来源：V. Mnih et al., *Human-level control through deep reinforcement learning*, Nature 2015。

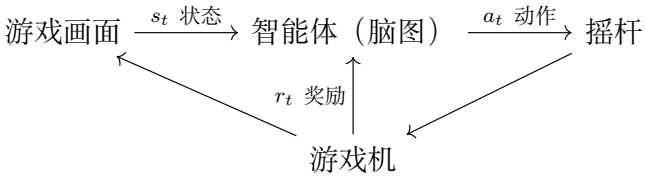

Deep Q-learning in Atari

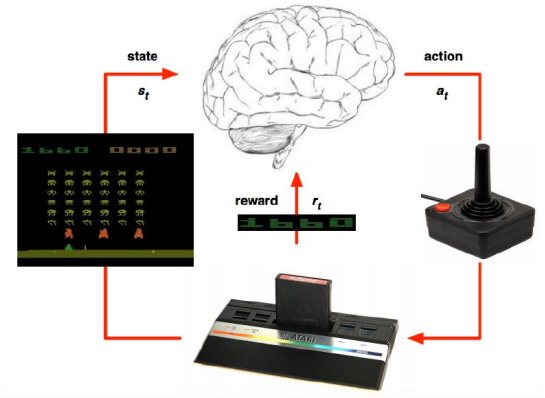

V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller,
Human-level control through deep reinforcement learning, *Nature* 2015

原课件第 20 页：Atari 中的深度 Q 学习（续）

从像素状态 s 端到端学习 $Q(s, a)$，输出对应 18 种摇杆 / 按键配置的 Q 值；奖励是该步得分变化。图示深度 Q 网络（DQN）。

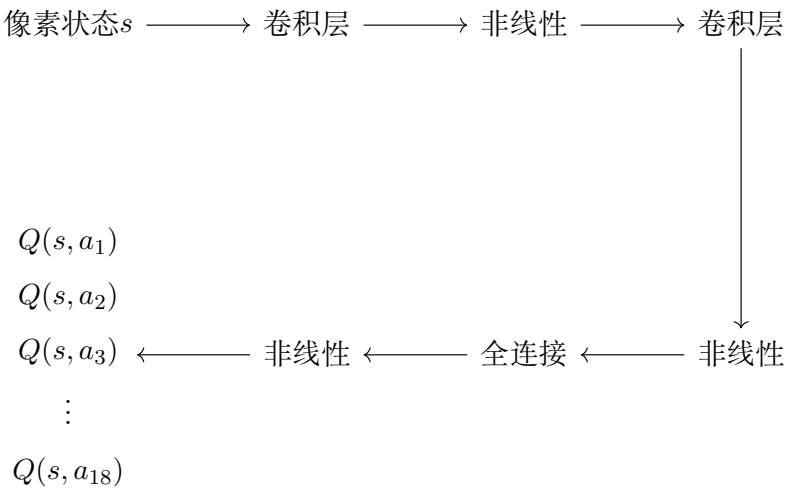

原图显示无输入、八个方向、单独按钮及方向与按钮组合，共 18 种配置；此处输出节点以同一列保留全部动作索引范围，不从图中推定未标的层尺寸。

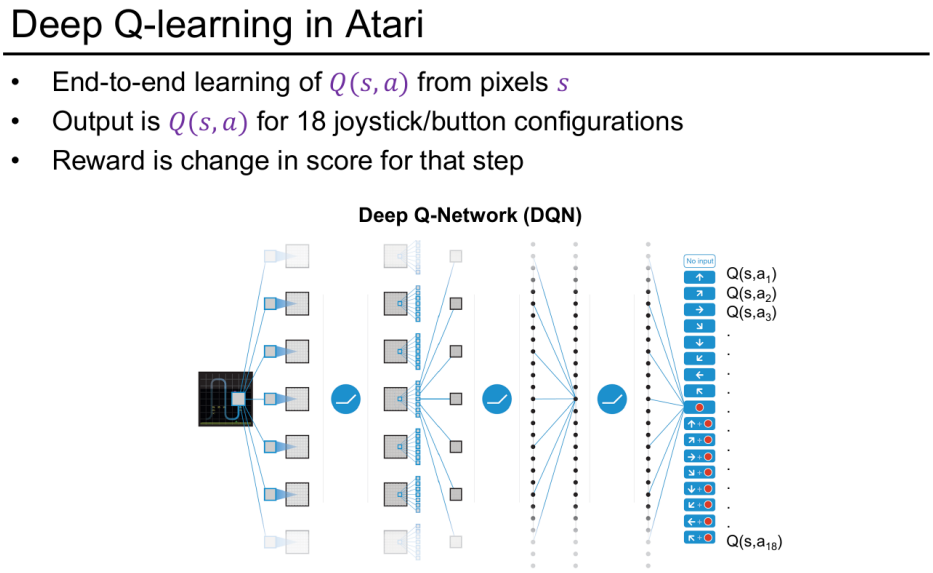

原课件第 21 页：Atari 中的深度 Q 学习（续）

输入状态为最近 4 帧的原始灰度像素堆叠；所有游戏使用固定的网络架构和超参数。图示四帧输入、卷积层、256 个隐单元及全连接线性输出层。

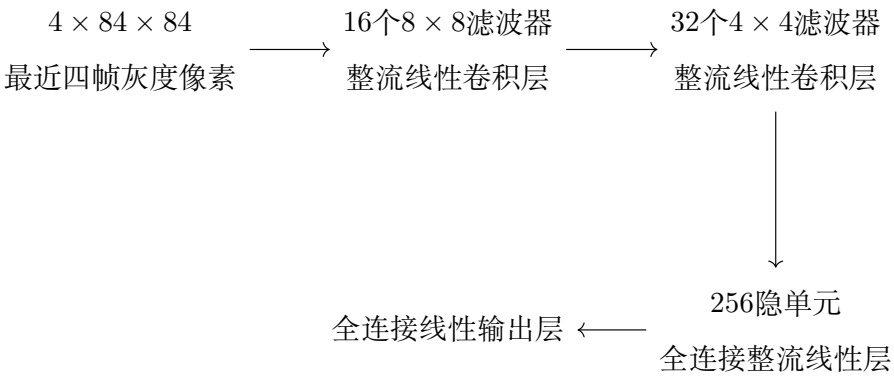

Deep Q-learning in Atari

- Input state is stack of raw pixels (grayscale) from last 4 frames
- Network architecture and hyperparameters fixed for all games

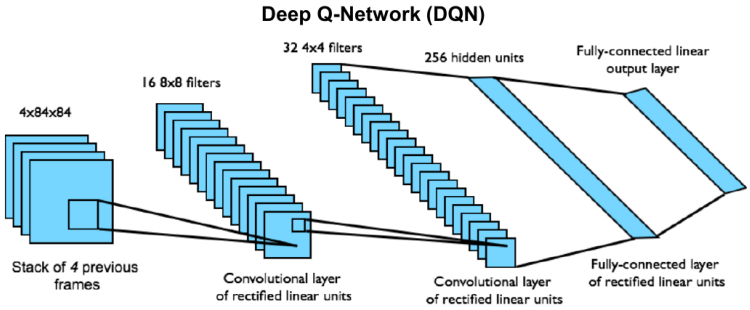

原课件第 22 页：Atari 中的深度 Q 学习（结果）

原图比较 Atari 各游戏中 DQN（蓝色）和最佳线性学习器（灰色）的成绩，以人类水平为 100% 的参照线；图中另标出达到或超过人类水平与低于人类水平的区域。下表抄录图中蓝色柱末端显示的 DQN 百分比，灰色柱在原图标出的数字另列于第二表；没有标注的灰色柱不由柱高推算。

游戏	DQN (%)	游戏	DQN (%)
Video Pinball	2539	Boxing	1707
Breakout	1327	Star Gunner	598
Robotank	508	Atlantis	451
Crazy Climber	419	Gopher	400
Demon Attack	294	Name This Game	278
Krull	277	Assault	246
Road Runner	232	Kangaroo	224
Tennis	148	James Bond	145
Pong	132	Space Invaders	121
Beam Rider	119	Tutankham	112
Kung-Fu Master	102	Freeway	102
Time Pilot	100	Enduro	97
Fishing Derby	93	Up and Down	92
Ice Hockey	79	Q*Bert	78
H.E.R.O.	76	Asterix	69
Battle Zone	67	Wizard of Wor	67
Chopper Command	64	Centipede	62
Bank Heist	57	River Raid	57

游戏	DQN (%)	游戏	DQN (%)
Amidar	43	Alien	42
Venture	32	Seaquest	25
Double Dunk	17	Bowling	14
Ms. Pacman	13	Asteroids	7
Frostbite	6	Gravitar	5
Private Eye	2	Montezuma's Revenge	0

游戏	最佳线性学习器 (%)	游戏	最佳线性学习器 (%)
Video Pinball	336	Boxing	1045
Breakout	14	Star Gunner	4
Robotank	273	Atlantis	308
Crazy Climber	51	Gopher	102
Demon Attack	11	Name This Game	11
Krull	222	Assault	31
Road Runner	0	Kangaroo	52
Tennis	159	James Bond	86
Pong	10	Space Invaders	7
Beam Rider	25	Tutankham	65
Kung-Fu Master	128	Freeway	66
Time Pilot	7	Enduro	51
Fishing Derby	6	Up and Down	35
Ice Hockey	66	Q*Bert	5
H.E.R.O.	25		

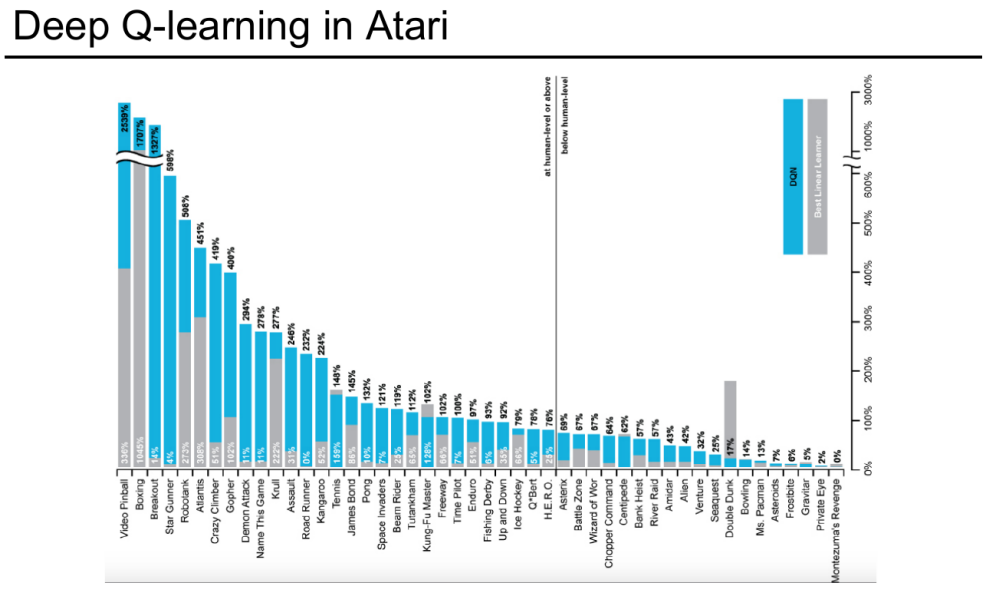

原课件第 23 页：Breakout 演示

原页显示 Breakout 游戏画面。视频链接：
https://www.youtube.com/watch?v=TmPfTpjtdgg。

原课件第 24 页：扩展——双重 Q 学习

原页称标准 Q 学习用最大算子同时选择和评价动作，导致 Q 值系统性高估。修改方法是用在线（当前）网络选择动作，用目标网络评价 Q 值：

$$y_{\text{target}}(s,a) = r(s) + \gamma \max_{a'} Q_{\text{target}}(s',a') \qquad \text{普通 DQN},$$

$$y_{\text{target}}(s,a) = r(s) + \gamma Q_{\text{target}}\left(s', \arg\max_{a'} Q_w(s',a')\right) \qquad \text{Double DQN}.$$

来源：H. van Hasselt, A. Guez, D. Silver, *Deep Reinforcement Learning with Double Q-learning*, AAAI 2016。

原课件第 25 页：Double DQN 结果

原图按游戏比较调优后的 Double DQN（蓝色）、Double DQN（白色）和 DQN（红色）的标准化分数，灰色虚线标示人类水平。纵轴在高分段采用分段刻度；各游戏柱形没有精确数值标签，应直接阅读原图，不能从柱高臆造精确数字。

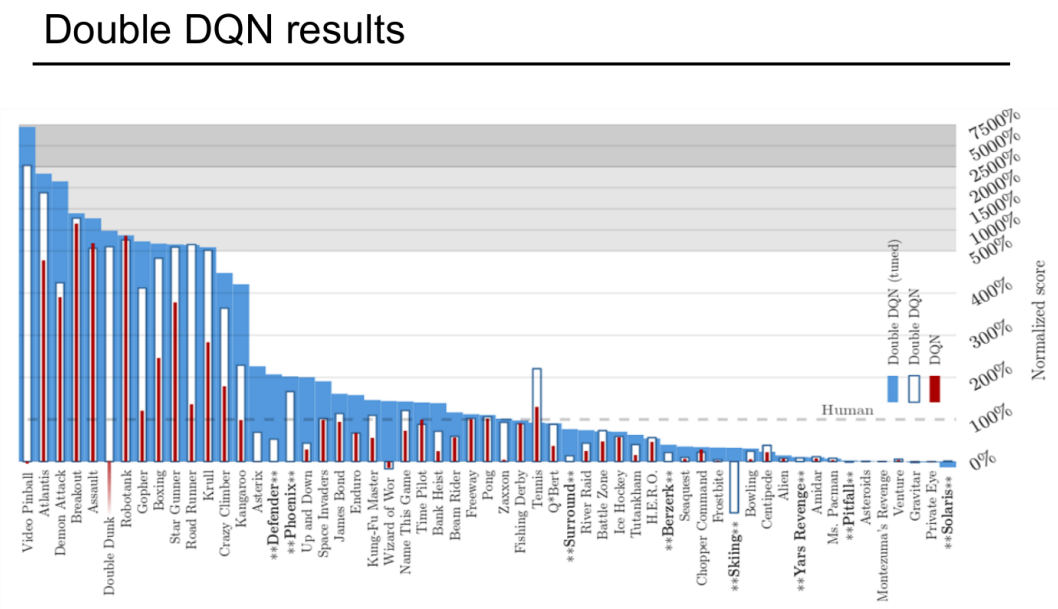

原课件第 26 页：另一种扩展——Dueling DQN

将 Q 函数估计分解为价值函数和优势函数。图示网络分别输出价值与优势，再组合为 Q 函数。来源：Z. Wang et al., *Dueling Network Architectures for Deep Reinforcement Learning*, ICML 2016。

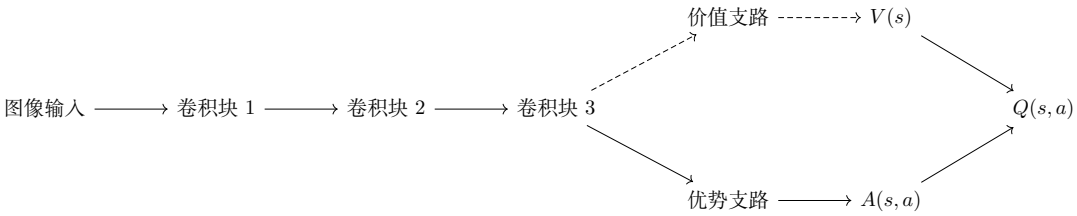

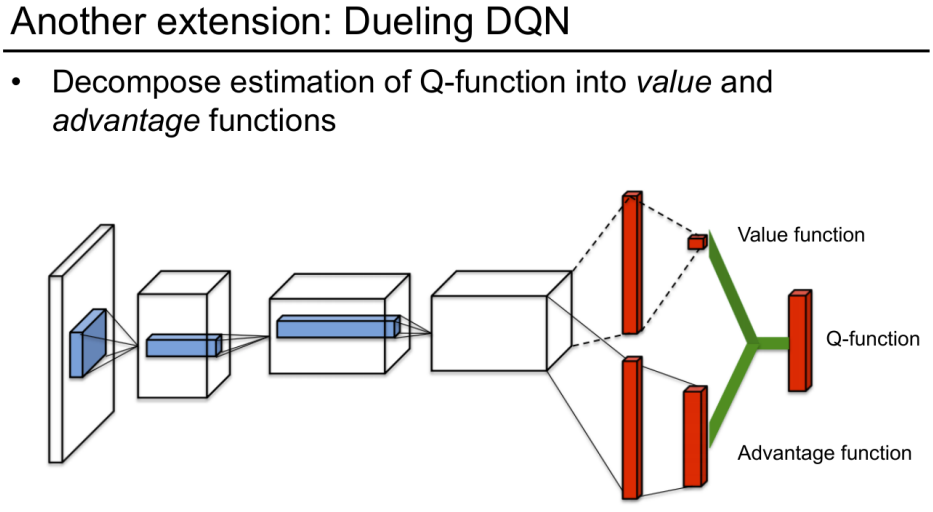

Z. Wang et al., Dueling Network Architectures for Deep Reinforcement Learning, ICML 2016

原课件第 27 页：Dueling DQN（续）

动机：在许多状态下，动作不会对环境产生有意义的影响，因此不需要在每个时刻知道每个动作的精确价值。原图对比游戏场景中价值与优势。来源同上一页。

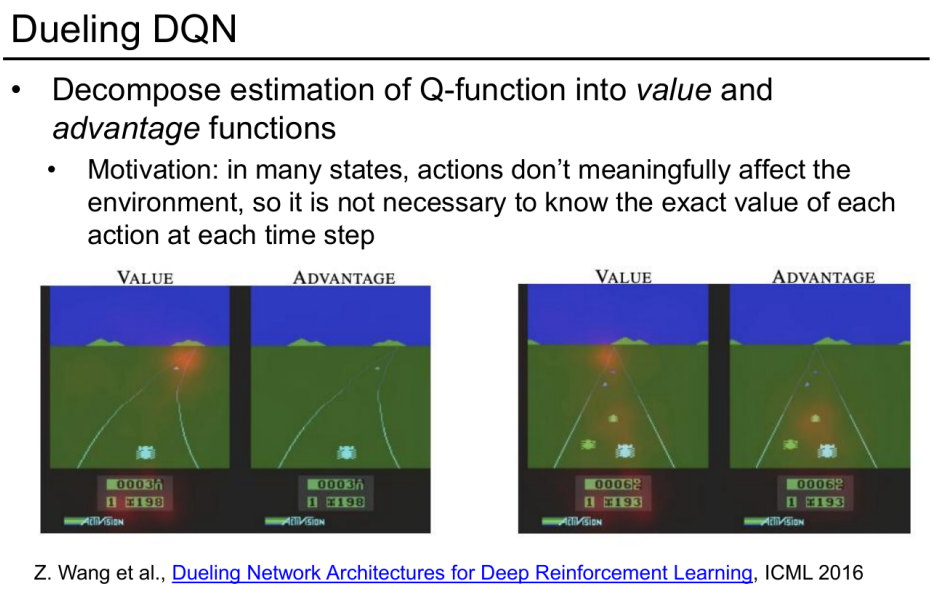

原课件第 28 页：Dueling DQN 分解

$$Q(s,a) = V(s) + A(s,a) - \max_{a'} A(s,a'),$$

或

$$Q(s,a) = V(s) + A(s,a) - \frac{1}{|\mathcal{A}|}\sum_{a'} A(s,a').$$

来源同上。

原课件第 29 页：Dueling DQN 结果

原图展示相对于优先回放 Double DQN 基线的改进。下表按原图抄录每个游戏标注的百分比；负数表示图中相对基线下降。

游戏	改进 (%)	游戏	改进 (%)
Asterix	1097.02	Space Invaders	457.93
Phoenix	281.56	Gopher	223.03
Wizard Of Wor	178.13	Up and Down	113.47
Yars' Revenge	113.16	Star Gunner	98.69
Berzerk	83.91	Video Pinball	74.20
Frostbite	70.29	Chopper Command	58.87
Assault	51.07	Bank Heist	43.11
River Raid	38.56	Defender	35.33

游戏	改进 (%)	游戏	改进 (%)
Name This Game	33.09	Zaxxon	32.74
Centipede	32.48	Beam Rider	29.94
Amidar	24.98	Kung-Fu Master	22.36
Tutankham	21.38	Crazy Climber	16.16
Q*Bert	15.56	Battle Zone	11.46
Atlantis	11.16	Enduro	10.20
Krull	7.95	Road Runner	7.89
Pitfall!	5.33	Boxing	3.46
Demon Attack	1.44	Fishing Derby	1.37
Pong	0.73	Private Eye	0.01
Montezuma's Revenge	0.00	Tennis	0.00
Venture	-0.51	Bowling	-0.87
Freeway	-2.08	Breakout	-2.12
Asteroids	-3.13	Alien	-3.81
H.E.R.O.	-6.72	Gravitar	-9.77
Ice Hockey	-13.60	Time Pilot	-29.21
Solaris	-37.65	Surround	-40.74
Ms. Pac-Man	-48.03	Robotank	-58.11
Seaquest	-60.56	Skiing	-77.99
Double Dunk	-83.56	James Bond	-84.70
Kangaroo	-89.22		

Dueling DQN: Results

Improvements over prioritized DDQN baseline:

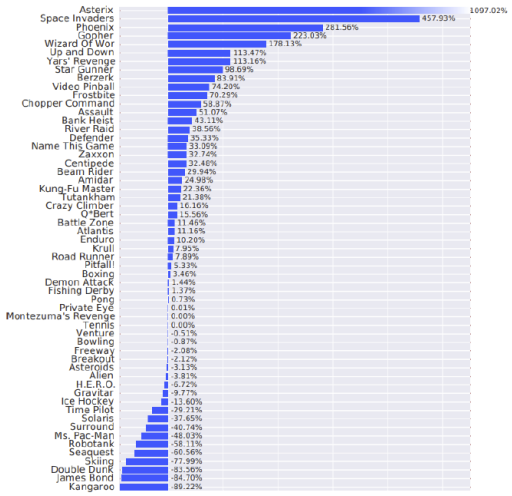

第 5 份课件：策略梯度、基于模型的强化学习与生成模型

原课件第 1 页：封面

CS 6804：世界模型；Chris Thomas，Virginia Tech 计算机科学系，2026 年秋季。许多幻灯片改编自 Graumann、Kovashka、Lazebnik、Fouhey、Lowe、Seitz、Batra、Forsyth、Fei-Fei Li 和 Hoiem 的材料。

原课件第 2 页：无模型方法与模型带来的变化

此前 Q 值和策略通过真实交互学习；世界模型不取代这一机制，而是改变数据：使用想象展开而非真实展开。Dreamer 在模型内部训练行动者与评论家。图示内部世界模型与外部环境；来源：arXiv:2606.12783, Fig. 3。

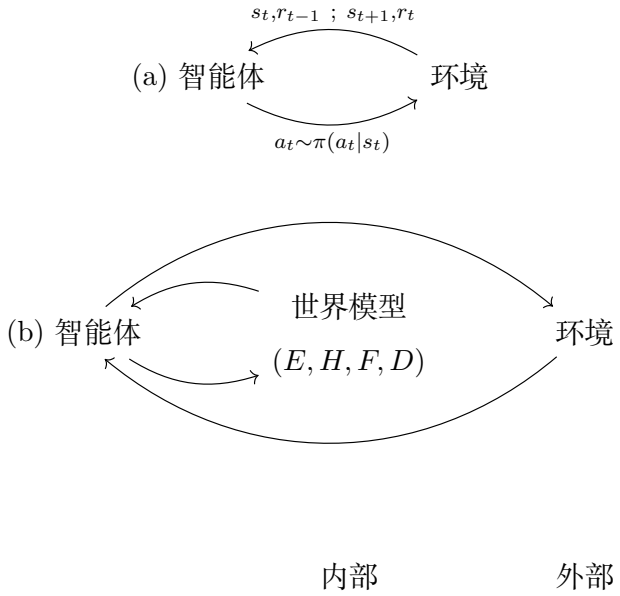

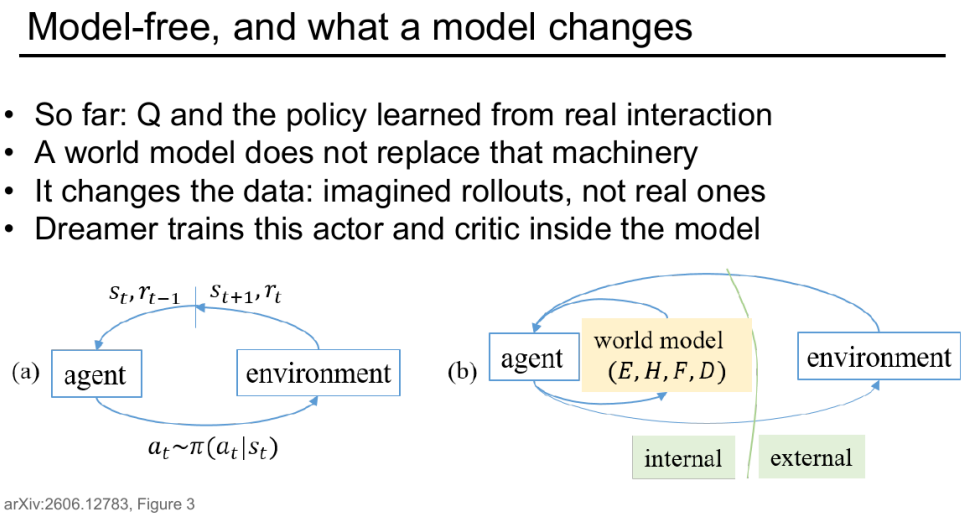

原课件第 3 页：策略梯度方法

原图示意状态 s_t 经策略网络 $\pi_\theta(a_t \mid s_t)$ 产生动作 a_t。

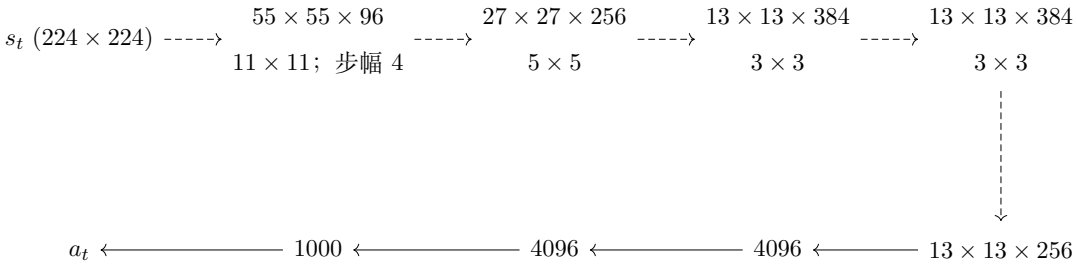

按原图保留 55、27、13 的空间尺寸与 96、256、384 的通道数，三处 Max pooling 分别位于第一、第二、第五卷积层后；4096 至 4096 之间标 dense。中部整条网络标为 $\pi_\theta(a_t \mid s_t)$，输入/动作图像仍见原截图。

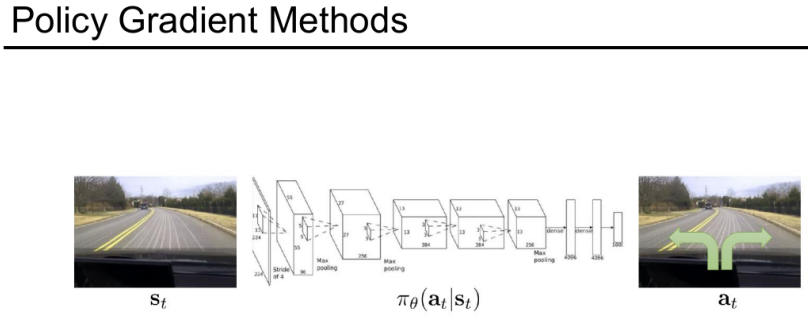

Image source

原课件第 4 页：提纲

随机策略表示；求策略梯度；REINFORCE 算法；行动者–评论家算法；基于模型的强化学习与世界模型；应用。

原课件第 5 页：策略梯度方法的动机

不通过 Q 值间接表示策略，而直接参数化并学习策略可能更有效，尤其在大型或连续动作空间中。图源：OpenAI Gym。

Policy gradient methods: Motivation

- Instead of indirectly representing the policy using Q-values, it can be more efficient to parameterize and learn it directly
  - Especially in large or continuous action spaces

Image source: OpenAI Gym

原课件第 6 页：随机策略表示

学习一个函数，给出当前状态下动作的概率分布：$\pi_\theta(a \mid s) \approx P(a \mid s)$。

原课件第 7 页：为什么使用随机策略？

原页指出，有些网格世界情形中只有随机策略才能达到最优；图中智能体无法区分灰色格子。**译注：**该例附有灰格观测混淆的限制，不是对任意完全可观测 MDP 的断言。来源：D. Silver。

Stochastic policy representation

- Learn a function giving the probability distribution over actions from the current state:

$$\pi_\theta(a|s) \approx P(a|s)$$

- Why stochastic policies?
  - There are examples even of grid world scenarios where only a stochastic policy can reach optimality

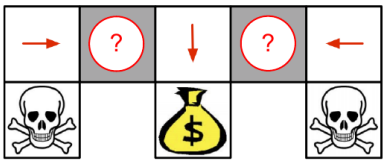

Source: D. Silver

The agent can't tell the difference between the gray cells

原课件第 8 页：随机策略表示（续）

随机策略在数学上很方便。原页给出 softmax 策略及连续动作空间的高斯策略：

$$\pi_\theta(a \mid s) = \frac{\exp(f_\theta(s,a))}{\sum_{a'} \exp(f_\theta(s,a'))},$$

$$\pi_\theta(a \mid s) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(a - f_\theta(s))^2}{2\sigma^2}\right).$$

原课件第 9 页：策略的期望价值

$$J(\theta)=\mathbb{E}\left[\sum_{t\geq 0}\gamma^t r_t \mid \pi_\theta\right]=\mathbb{E}_\tau[r(\tau)]=\int_\tau r(\tau)p(\tau;\theta)\,d\tau.$$

这里对轨迹 $\tau=(s_0,a_0,r_0,s_1,a_1,r_1,\ldots)$ 的回报取期望，$p(\tau;\theta)$ 是参数为 θ 的策略下的轨迹概率。

原课件第 10 页：求策略梯度

$$\begin{aligned}\nabla_\theta J(\theta)&=\int_\tau r(\tau)\nabla_\theta p(\tau;\theta)\,d\tau\\&=\int_\tau r(\tau)p(\tau;\theta)\frac{\nabla_\theta p(\tau;\theta)}{p(\tau;\theta)}\,d\tau\\&=\int_\tau r(\tau)p(\tau;\theta)\nabla_\theta\log p(\tau;\theta)\,d\tau\\&=\mathbb{E}_\tau[r(\tau)\nabla_\theta\log p(\tau;\theta)].\end{aligned}$$

译注：该得分函数推导需要相应可微性、微分与积分可交换以及支持集/可积性条件；这里的概率比只在有定义的支撑上使用。原页未列这些条件，不能作为对任意策略族和无限轨迹的无条件结论。

原课件第 11 页：轨迹概率和得分函数

$$\begin{aligned}p(\tau;\theta)&=P(s_0)\prod_{t\geq 0}\pi_\theta(a_t\mid s_t)P(s_{t+1}\mid s_t,a_t),\\\log p(\tau;\theta)&=\log P(s_0)+\sum_{t\geq 0}\left[\log\pi_\theta(a_t\mid s_t)+\log P(s_{t+1}\mid s_t,a_t)\right],\\\nabla_\theta\log p(\tau;\theta)&=\sum_{t\geq 0}\nabla_\theta\log\pi_\theta(a_t\mid s_t).\end{aligned}$$

最后一项称得分函数；原推导隐含初始分布及环境转移不依赖 θ。

原课件第 12 页：得分函数 $\nabla_\theta\log\pi_\theta(a\mid s)$

原页对 softmax 策略写出

$$\nabla_\theta\log\pi_\theta(a_t\mid s_t)=\nabla_\theta f_\theta(s,a)-\sum_{a'}\pi_\theta(a'\mid s)\nabla_\theta f_\theta(s,a').$$

对第 8 页的高斯策略，原页写出

$$\nabla_\theta\log\pi_\theta(a_t\mid s_t)=\frac{a-f_\theta(s)}{\sigma^2}\nabla_\theta f_\theta(s)-\text{const}.$$

左右两侧使用 (s_t,a_t) 与 (s,a) 的不同记号，均依源保留。**译注：**若方差固定且不依赖 θ，高斯对数密度中归一化常数的导数为零，不应额外留下非零常数；若方差也是待学习参数，还会有相应参数导数。这里保留源式末尾的 $-\text{const}.$，不把它解释为已确定的梯度项。

原课件第 13 页：策略梯度（续）

将轨迹回报和动作对数似然梯度相乘：

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau\left[\left(\sum_{t\ge 0}\gamma^t r_t\right)\left(\sum_{t\ge 0}\nabla_\theta \log \pi_\theta(a_t \mid s_t)\right)\right].$$

如何在实践中估计该梯度？

原课件第 14 页：随机近似

采样 N 条轨迹 $\tau_1,\dots,\tau_N$，用原页所示估计：

$$\nabla_\theta J(\theta) \approx \frac{1}{N}\sum_{i=1}^{N}\left(\sum_{t=0}^{T_i}\gamma^t r_{i,t}\right)\left(\sum_{t=0}^{T_i}\nabla_\theta \log \pi_\theta(a_{i,t} \mid s_{i,t})\right).$$

原课件第 15 页：REINFORCE 算法

1. 用当前策略 π_θ 采样 N 条轨迹 τ_i。
2. 估计策略梯度：

$$\nabla_\theta J(\theta) \approx \frac{1}{N}\sum_{i=1}^{N} r(\tau_i)\left(\sum_{t=0}^{T_i}\nabla_\theta \log \pi_\theta(a_{i,t} \mid s_{i,t})\right).$$

3. 以梯度上升更新：$\theta \leftarrow \theta + \eta \nabla_\theta J(\theta)$。

来源：Williams et al., *Simple statistical gradient-following algorithms for connectionist reinforcement learning*, Machine Learning 8(3):229–256, 1992。

原课件第 16 页：REINFORCE 的单步版本

1. 在状态 s 下用当前策略采样动作 a，观察奖励 r。
2. 估计梯度 $\nabla_\theta J(\theta) \approx r \nabla_\theta \log \pi_\theta(a \mid s)$。
3. 以 $\theta \leftarrow \theta + \eta \nabla_\theta J(\theta)$ 作梯度上升。

原页称这会提高好动作概率、降低坏动作概率。**译注：**对一次采样动作，这是一阶、小步长且对数策略可微时、相对于奖励符号的直观解释；共享参数、有限步长或多动作联动时，不保证所有动作或所有状态的概率都按此方向单调改变。

原课件第 17 页：提纲

继随机策略、策略梯度和 REINFORCE 后，接下来介绍行动者–评论家算法。

原课件第 18 页：降低方差

单条轨迹的梯度估计为

$$\nabla_\theta J(\theta) \approx \sum_{t\geq 0} r(\tau)\nabla_\theta \log \pi_\theta(a_t \mid s_t).$$

一般问题是采样轨迹的奖励噪声过大，导致策略梯度不可靠。

原课件第 19 页：降低方差（续）

用整条轨迹的回报为每个动作加权似乎不合理，特别是采取动作之前得到的奖励不应为该动作加权。原页建议每个动作只考虑其后的累积未来奖励：

$$\nabla_\theta J(\theta) \approx \sum_{t\geq 0} \left(\sum_{t'\geq t} \gamma^{t'-t} r_{t'} \right) \nabla_\theta \log \pi_\theta(a_t \mid s_t).$$

译注：对于第 9 页从初始时刻折扣的目标，若按普通轨迹时间步直接求和，相应未来回报项还带外层 γ^t；也可把该权重吸收到另行定义的折扣状态访问分布中。源页未说明这种采样约定，故此处保留其公式，不能直接视为与前述目标无条件等价。此限制同样适用于后面省略该权重的 Q 值/优势形式。

原课件第 20 页：降低方差（续）

上一页括号内是状态 s_t 下采取 a_t 后观测到的累积奖励。原页进一步提出使用期望累积奖励：

$$\nabla_\theta J(\theta) \approx \sum_{t\geq 0} Q^{\pi_\theta}(s_t, a_t)\nabla_\theta \log \pi_\theta(a_t \mid s_t).$$

原课件第 21 页：行动者–评论家算法

同时训练行动者（策略）与评论家（Q 函数），将策略梯度与 Q 学习结合。图中行动者–评论家位于基于价值和基于策略方法的交集。来源：D. Silver。

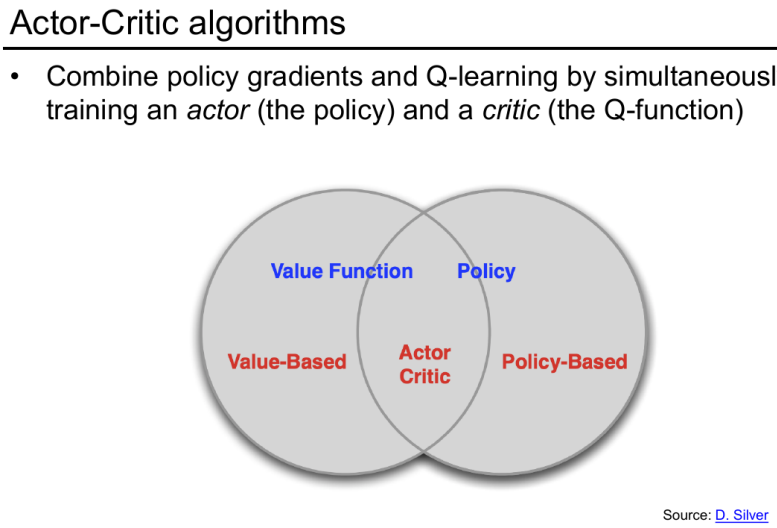

原课件第 22 页：以基线降低方差

原页指出，原始 Q 值并非最有用：如果所有 Q 值都好，便会试图提高所有动作的概率。可将动作的 Q 值与状态的基线函数比较：

$$\nabla_\theta J(\theta) \approx \sum_{t \geq 0} \left[Q^{\pi_\theta}(s_t, a_t) - V^{\pi_\theta}(s_t) \right] \nabla_\theta \log \pi_\theta(a_t \mid s_t).$$

方括号为优势函数 $A^{\pi_\theta}(s_t, a_t)$。

原课件第 23 页：估计优势函数

$$\begin{aligned} A^{\pi_\theta}(s,a) &= Q^{\pi_\theta}(s,a) - V^{\pi_\theta}(s) \\ &= \mathbb{E}_{s'}[r + \gamma V^{\pi_\theta}(s') \mid s, a] - V^{\pi_\theta}(s) \\ &\approx r + \gamma V^{\pi_\theta}(s') - V^{\pi_\theta}(s), \end{aligned}$$

最后一行由单个转移得到。原页因此提出只需学习价值函数 $V^{\pi_\theta}(s) \approx V_w(s)$。

原课件第 24 页：在线行动者–评论家算法

1. 使用当前策略采样动作 a，观察奖励 r 和后继状态 s'。
2. 将 $V_w(s)$ 朝目标 $r + \gamma V_w(s')$ 更新。
3. 估计 $A^{\pi_\theta}(s,a) = r + \gamma V_w(s') - V_w(s)$。
4. 估计 $\nabla_\theta J(\theta) = A^{\pi_\theta}(s,a) \nabla_\theta \log \pi_\theta(a \mid s)$。
5. 更新策略参数 $\theta \leftarrow \theta + \eta \nabla_\theta J(\theta)$。

原图显示生成样本、拟合模型估计回报、改进策略的循环。来源：Berkeley RL course。第 3、4 步等号为原页估计记号，非声称精确值。

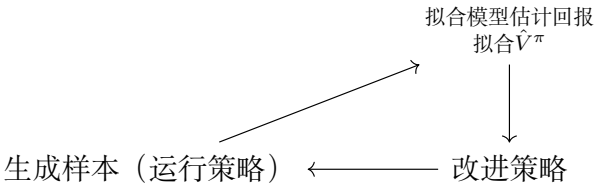

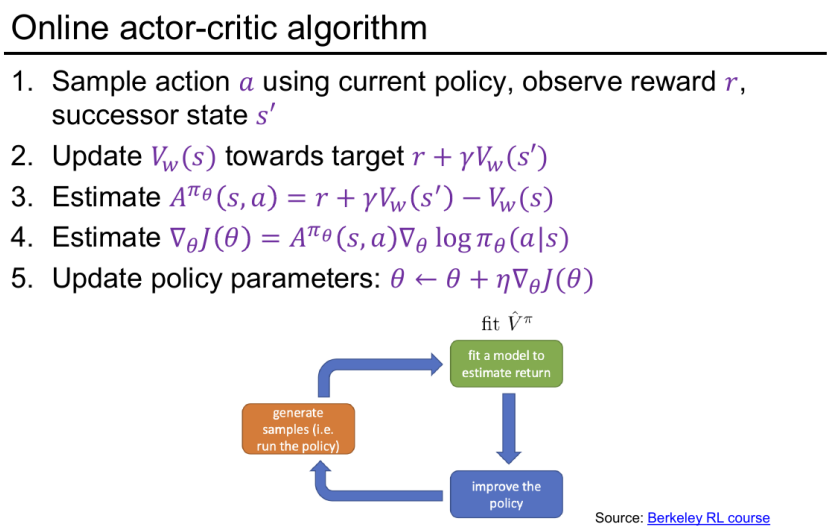

原课件第 25 页：异步优势行动者–评论家（A3C）

多个智能体各自生成经验并局部更新，再异步更新全局参数 V, π。来源：Mnih et al., *Asynchronous Methods for Deep Reinforcement Learning*, ICML 2016。

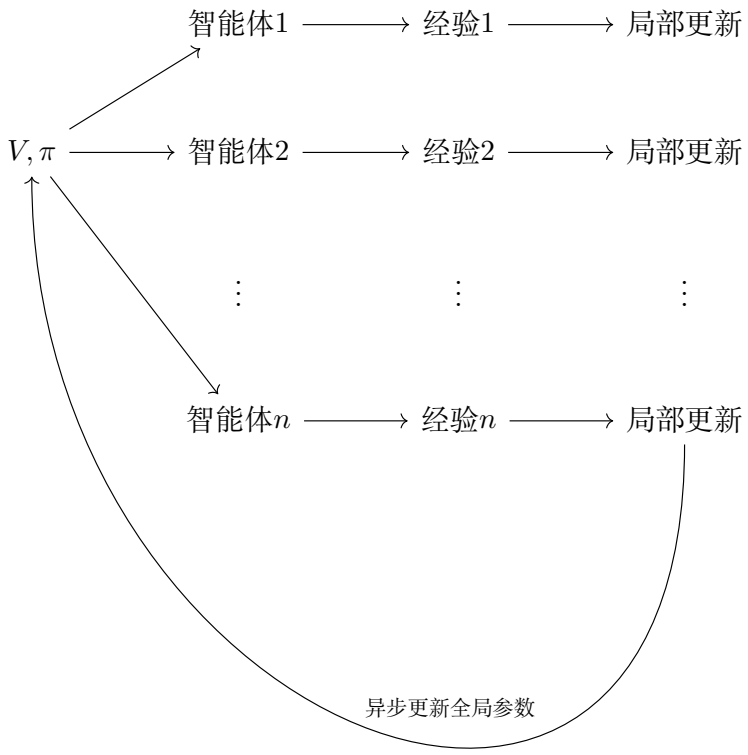

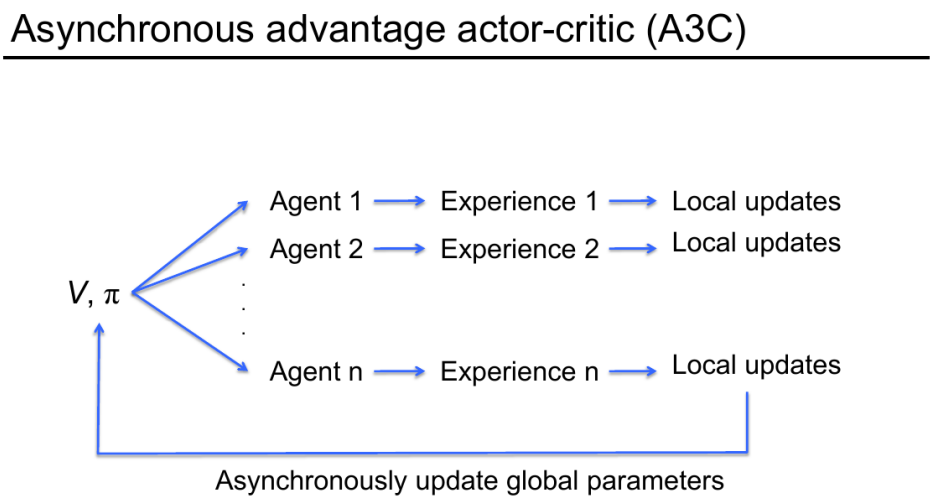

Mnih et al. Asynchronous Methods for Deep Reinforcement Learning. ICML 2016

原课件第 26 页：A3C 结果

原表列出 57 个 Atari 游戏的人类归一化分数均值及中位数：

方法	训练时间	均值	中位数
DQN	GPU 8 天	121.9%	47.5%
Gorila	100 台机器 4 天	215.2%	71.3%
D-DQN	GPU 8 天	332.9%	110.9%
Dueling D-DQN	GPU 8 天	343.8%	117.1%
Prioritized DQN	GPU 8 天	463.6%	127.6%
A3C, FF	CPU 1 天	344.1%	68.2%
A3C, FF	CPU 4 天	496.8%	116.6%
A3C, LSTM	CPU 4 天	623.0%	112.6%

来源同上一页。

Asynchronous advantage actor-critic (A3C)

Method	Training Time	Mean	Median
DQN	8 days on GPU	121.9%	47.5%
Gorila	4 days, 100 machines	215.2%	71.3%
D-DQN	8 days on GPU	332.9%	110.9%
Dueling D-DQN	8 days on GPU	343.8%	117.1%
Prioritized DQN	8 days on GPU	463.6%	127.6%
A3C, FF	1 day on CPU	344.1%	68.2%
A3C, FF	4 days on CPU	496.8%	116.6%
A3C, LSTM	4 days on CPU	623.0%	112.6%

Mean and median human-normalized scores over 57 Atari games

Mnih et al. Asynchronous Methods for Deep Reinforcement Learning. ICML 2016

原课件第 27 页：A3C 赛车演示

原页显示 TORCS 赛车模拟视频截图。来源同第 25 页。

Asynchronous advantage actor-critic (A3C)

TORCS car racing simulation video

Mnih et al. Asynchronous Methods for Deep Reinforcement Learning. ICML 2016

原课件第 28 页：A3C 运动控制演示

原页显示运动控制任务视频截图。来源同第 25 页。

Asynchronous advantage actor-critic (A3C)

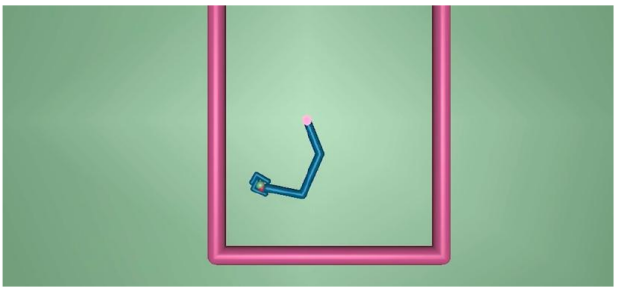

Motor control tasks video

Mnih et al. Asynchronous Methods for Deep Reinforcement Learning. ICML 2016

原课件第 29 页：近端策略优化（PPO）

原页称标准行动者–评论家算法是同策略的，不能对同一批样本执行多次更新；PPO 通过一个小心限制每次策略变化幅度的复杂“代理目标”，使同一小批量可用于多次更新。原图算法依次对 N 个行动者运行旧策略 T 步、计算优势估计，对代理目标用 K 个 epoch 和大小 $M \le NT$ 的小批量优化，再令 $\theta_{\text{old}} \leftarrow \theta$。来源：J. Schulman et al., *Proximal Policy Optimization Algorithms*, arXiv 2017。原页算法 1（PPO，行动者–评论家形式）完整步骤：

1. 对迭代 $1, 2, \ldots$ 重复下列步骤。

   (a) 对行动者 $1, 2, \ldots, N$，在环境中运行策略 $\pi_{\theta_{\text{old}}}$ 共 T 步，并计算优势估计 $\hat{A}_1, \ldots, \hat{A}_T$；完成各行动者循环。

   (b) 相对于 θ 优化代理目标 L，使用 K 个 epoch 和大小 $M \le NT$ 的小批量。

   (c) 令 $\theta_{\text{old}} \leftarrow \theta$，完成本次迭代后返回外层循环。

Proximal policy optimization (PPO)

- Standard actor-critic algorithms are *on-policy*, cannot perform multiple update steps using the same set of samples
- PPO enables multiple updates using the same minibatch of samples by using a complicated “surrogate objective” that carefully restricts how much the policy can change each time

Algorithm 1 PPO, Actor-Critic Style

for iteration=$1, 2, \ldots$ **do**
  for actor=$1, 2, \ldots, N$ **do**
    Run policy $\pi_{\theta_{\text{old}}}$ in environment for T timesteps
    Compute advantage estimates $\hat{A}_1, \ldots, \hat{A}_T$
  end for
  Optimize surrogate L wrt θ, with K epochs and minibatch size $M \le NT$
  $\theta_{\text{old}} \leftarrow \theta$
end for

J. Schulman et al. Proximal Policy Optimization Algorithms. arXiv 2017

原课件第 30 页：PPO 的概率比

用旧策略 $\pi_{\theta_{\text{old}}}$ 收集数据，再在同一批数据上更新新策略 π_θ，以

$$r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)}$$

衡量每个采样动作概率的变化。若优势估计 $\hat{A}_t > 0$，动作好于预期，希望比值增加；若 $\hat{A}_t < 0$，动作差于预期，希望比值减小。普通策略梯度代理目标为

$$L^{PG}(\theta) = \hat{\mathbb{E}}_t[r_t(\theta)\hat{A}_t].$$

问题是经过多个 epoch 后，π_θ 可能离 $\pi_{\theta_{\text{old}}}$ 很远。来源同上一页。

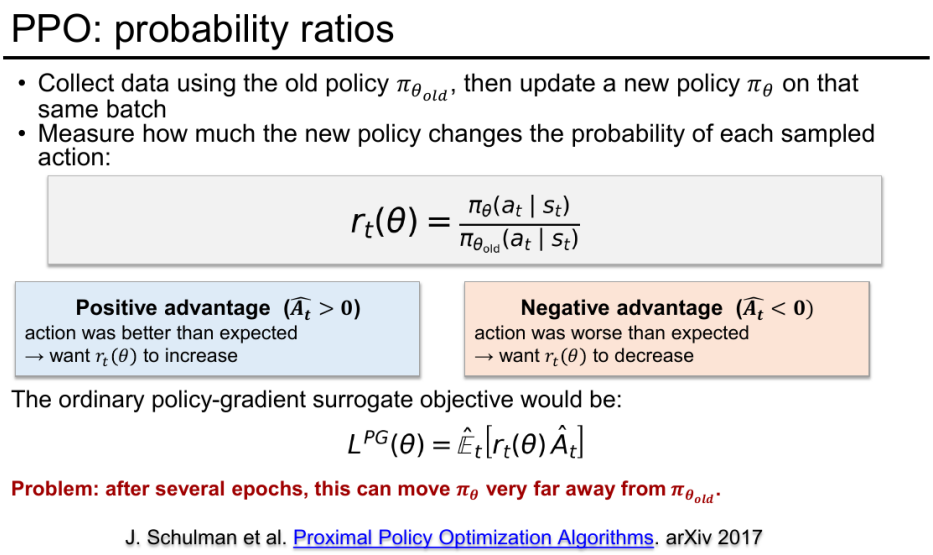

原课件第 31 页：PPO 裁剪代理目标

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t\left[\min\left(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right].$$

原页将裁剪描述为在旧策略周围施加软信赖区域；取最小值选择较悲观的目标，因此将好动作继续推过裁剪边界不会得到额外奖励。典型 $\epsilon \approx 0.2$，采样动作概率变化超过约 20% 会受到抑制。课件称这使 PPO 通常可以复用同一批样本进行 K 个小批量 epoch，而不破坏策略，并将其概括为“行动者–评论家加策略变化速度限制”。图示概率比区间 $[1-\epsilon, 1+\epsilon]$。**译注：**裁剪并非对策略变化的严格约束。对单个采样项，仅当 $\hat{A}_t > 0$ 且 $r_t > 1+\epsilon$，或 $\hat{A}_t < 0$ 且 $r_t < 1-\epsilon$ 时，裁剪一侧形成平台；区间外的另一侧仍可能有梯度。源图“区间外不再获得梯度奖励”的口号不能解释为任意区间外更新梯度都为零，更不能保证 KL 或实际性能变化有硬界。来源：J. Schulman et al., *Proximal Policy Optimization Algorithms*, arXiv 2017。

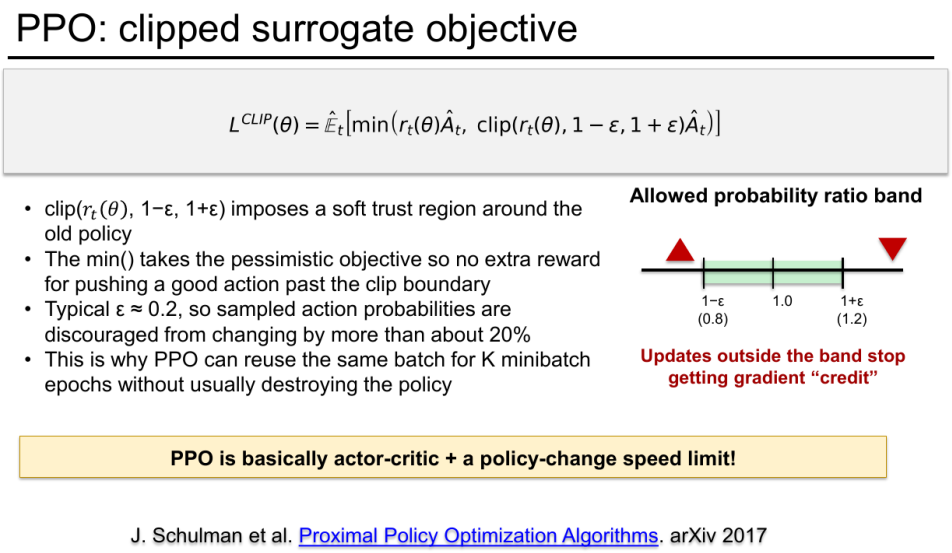

原课件第 32 页：基于模型的强化学习与世界模型

到目前为止，学习仅使用智能体实际经历的转移；如果保留这些转移的模型，会有什么变化？

原课件第 33 页：提纲

接下来是基于模型的强化学习与世界模型，以及应用。

原课件第 34 页：此前都从真实交互学习

Q 学习和 DQN 从实际转移拟合 Q；REINFORCE 对每条采样轨迹执行一次梯度步后丢弃；行动者–评论家及 A3C 使用评论家降低方差，数据仍是真实的；PPO 将一批数据复用几个 epoch 后再收集。原页指出梯度步要以环境步为代价，且这些方法没有显式预测环境接下来会做什么。

原课件第 35 页：这些算法的问题

- DQN（Nature 2015）每个游戏使用 5000 万帧，论文称约相当于 38 天游戏经验；49 个游戏各训练一个网络。比较的人类每个游戏约练习两小时。
- Atari 100k 使用 10 万次智能体决策，约两小时游戏，相当于 DQN 的五百分之一。PPO 在每个 MuJoCo 任务上用 100 万步，在 Atari 上用 1000 万步。
- 原页指出真实机器人无法承受这一代价：QT-Opt 需要 58 万次抓取尝试、7 台机器人和 4 个月来收集约 800 机器人小时。DayDreamer 使真实四足机器人不借助模拟器在一小时内站起并行走；同一小时内 SAC 从背部翻转却始终未站起。

以上数值和对比为课件说法，未独立核验外部论文实验。特别是“帧”与“智能体决策”并非天然相同计数口径，原页的五百分之一照录，不能由这些文字直接证明公平的样本预算比。

原课件第 36 页：被丢弃的转移模型

MDP 有状态、动作、转移模型 $P(s' \mid s, a)$ 和奖励；Bellman 方程以该转移模型表述。Q 学习通过采样转移和自举，使我们不必显式写下 P。基于模型的强化学习将其重新引入，但从智能体原本收集的同一批转移中拟合 $\hat{P}$。原页将问题归结为是否保留数据的模型。

原课件第 37 页：模型的三种用途

- 用模型规划：在决策时在模型内搜索动作序列，可完全不使用策略网络；例子为 PETS、带 CEM 的 MPC。
- 用模型生成数据：展开模型产生额外转移，用它们训练任意无模型学习器；例子为 Dyna、MBPO。
- 在模型中学习：对想象展开求导以训练行动者，评论家也在其中训练；例子为 Dreamer、PlaNet。此分类依原课件保留，具体方法训练机制待按原论文独立核对。

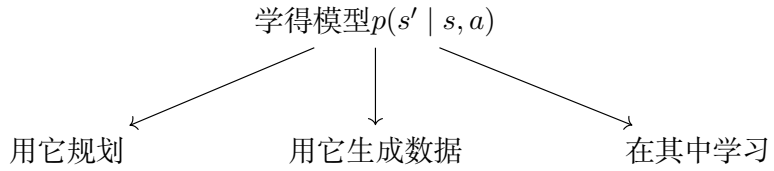

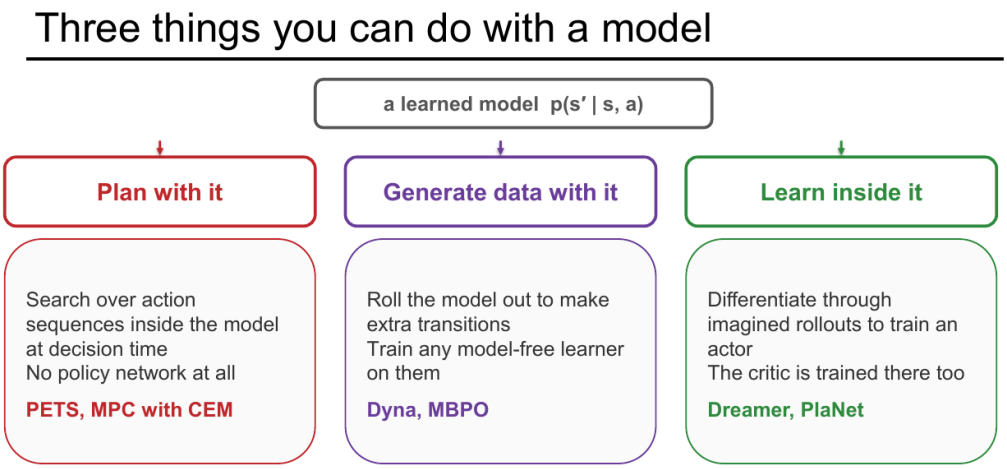

原课件第 38 页：决策时规划——MPC 中的 CEM

1. 采样：从高斯分布抽取数百条长度为 H 的动作序列。
2. 评分：将每条序列在模型中展开，累加预测奖励。
3. 重拟合：保留最好的几个百分点，拟合新的高斯分布，重复数次。

4. 行动：只执行第一个动作，丢弃其余动作，下一步重新规划。

原页指出此处没有策略网络或价值函数，唯一学习的对象是模型。

原课件第 39 页：在潜空间展开

一个较小的帧含 $64 \times 64 \times 3$ 个数，而潜状态是几百维向量。对大小为 16 的批次想象 15 步会产生 240 次可省去的解码器前向计算。解码器训练时有用，用以迫使状态保留帧内容；展开时不需要它，因为奖励头和价值头直接读取状态。所需的是能由转移模型向前推进的状态；课件将其描述为加入时间和动作的变分自编码器。

原课件第 40 页：变分自编码器

VAE 结合以下思想：

1. 自编码器。
2. 变分近似，包括变分下界。
3. 摊销推断神经网络。
4. 重参数化技巧。

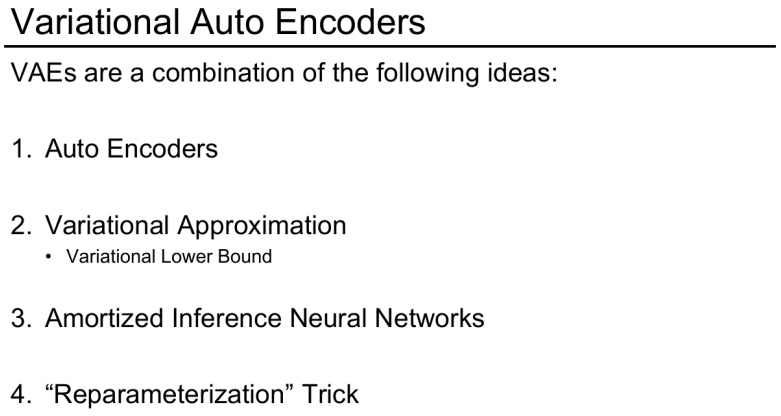

原课件第 41 页：自编码器

训练特征使其可重建原始数据。图示输入 x 经编码器得到特征 z，再经解码器得到重建 $\hat{x}$，使用 L_2 损失 $\|x - \hat{x}\|^2$。图中示例编码器为 4 层卷积、解码器为 4 层上采样卷积。课件致谢：Fei-Fei Li, Justin Johnson, Serena Yeung, CS 231n。

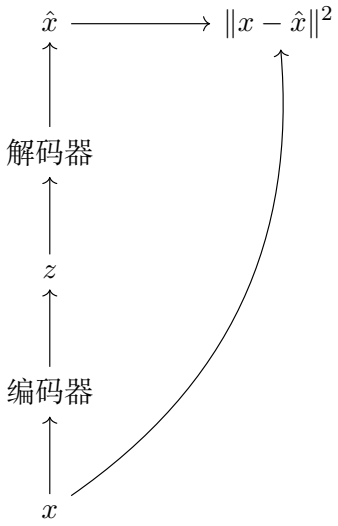

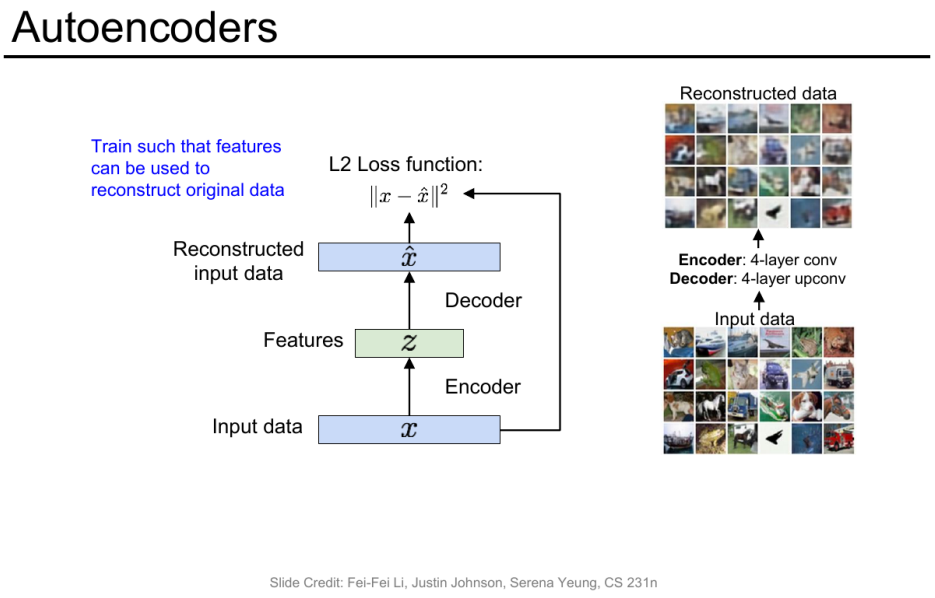

Slide Credit: Fei-Fei Li, Justin Johnson, Serena Yeung, CS 231n

原课件第 42 页：变分自编码器

对自编码器引入概率观点，使我们能够从模型中采样生成数据。图中编码器为 $q_\phi(z \mid x)$，解码器为 $p_\theta(x \mid z)$；分别由数据 x 到潜变量 z、由 z 到重建 $\hat{x}$。

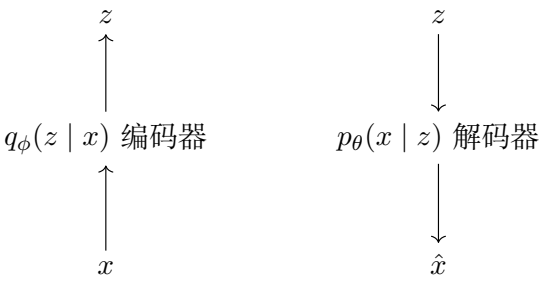

Variational Autoencoders

Probabilistic spin on autoencoders - will let us sample from the model to generate data!

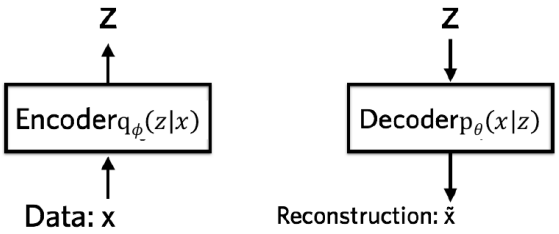

原课件第 43 页：变分推断

使用 Jensen 不等式得到下界。对于凸函数 h 和随机变量 X，$\mathbb{E}[h(X)] \geq h(\mathbb{E}[X])$；若 h 凹，则不等号反向。$\log z$ 凹，因此

$$\mathbb{E}[\log X] \leq \log \mathbb{E}[X].$$

图示对数函数及弦；不等式需要相关期望存在且对数有定义。

Variational inference

- We'll obtain the lower bound using Jensen's inequality
- Recall, for a convex function h of a random variable X:
$$\mathbb{E}[h(X)] \geq h(\mathbb{E}[X])$$
- So, if h is concave (i.e. $-h$ is convex):
$$\mathbb{E}[h(X)] \leq h(\mathbb{E}[X])$$
- The function $\log z$ is concave, so:
$$\mathbb{E}[\log(X)] \leq \log(\mathbb{E}[X])$$

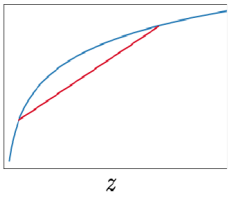

原课件第 44 页：变分下界（ELBO）

设有分布 $q(z)$，原页运用 Jensen 不等式给出下界；以下照原页排式，保留其第二行未显示积分号及后续省略的参数下标：

$$\begin{aligned}\log p_\theta(x) &= \log \int_z p_\theta(z) p_\theta(x \mid z)\, dz \\ &= \log q(z) \frac{p(z)}{q(z)} p(x \mid z)\, dz \\ &\geq \int_z q(z) \log \frac{p(z)}{q(z)} p(x \mid z)\, dz \\ &= \mathbb{E}_q\left[\log \frac{p(z)}{q(z)}\right] + \mathbb{E}_q[\log p(x \mid z)].\end{aligned}$$

第二行缺少积分号且括号不明确，第三行对数范围有歧义，不能直接把该字面排式视为已证明的下界。源页第 70 页另列通常的 ELBO 与 KL 间隙关系；支持与可积性条件见该页译注。本页仍忠实保留原排式，不静默把对数范围或缺失积分补成推测版本。

Variational lower bound (i.e. ELBO)

- Suppose we have some distribution $q(z)$ (we'll talk about where it comes from later), we can use Jensen's inequality to obtain the lower bound:

$$\begin{aligned}\log p_\theta(x) &= \log \int_z p_\theta(z) p_\theta(x|z) dz \\ &= \log q(z)\, \frac{p(z)}{q(z)} p(x|z)\, dz \\ &\geq \int_z q(z) \log \frac{p(z)}{q(z)} p(x|z)\, dz \\ &= \mathbb{E}_q\left[\log \frac{p(z)}{q(z)}\right] + \mathbb{E}_q[\log p(x|z)]\end{aligned}$$

- We'll look at each of these terms next

原课件第 45 页：KL 散度

$$D_{\mathrm{KL}}(q(z) \| p(z)) \triangleq \mathbb{E}_q\left[\log \frac{q(z)}{p(z)}\right].$$

这与上一页 $\mathbb{E}_q[\log(p(z)/q(z))]$ 相差负号。通常取 $p(z) = \mathcal{N}(0, I)$；可将其视为正则项，鼓励 z 的分布接近正态分布。

KL-divergence

$$\mathbb{E}_q\left[\log\frac{p(z)}{q(z)}\right]$$

$$D_{KL}(q(z)\|p(z)) \triangleq \mathbb{E}_q\left[\log\frac{q(z)}{p(z)}\right]$$

- Typically we choose $p(z) = \mathcal{N}(0, \boldsymbol{I})$.
- You can think of this as a regularizer
- It encourages our distributions on *z* to be close to the normal distribution

原课件第 46 页：重参数化技巧

为拟合 q，令其具有参数形式，如 $q(z) = \mathcal{N}(z; \mu, \Sigma)$，其中 $\mu = (\mu_1, \ldots, \mu_K)$，$\Sigma = \mathrm{diag}(\sigma_1^2, \ldots, \sigma_K^2)$。原页称不能对随机采样求导，但可使用

$$z_i = \mu_i + \sigma_i \epsilon_i, \qquad \epsilon_i \sim \mathcal{N}(0, 1).$$

原图对直接采样写 $z_i \sim \mathcal{N}(\mu_i, \Sigma_i)$，按源保留；**译注：**重参数化把与参数无关的噪声保持固定后，对确定性变换求路径导数；并不意味着所有随机采样都不可微，或任意分布都允许此变换及期望/微分交换。

Reparameterization trick

- To fit q, let's assign it to have a parametric form (e.g. a Gaussian): $q(z) = \mathcal{N}(z; \mu; \Sigma)$, where $\mu = (\mu_1, \ldots, \mu_K)$ and $\Sigma = diag(\sigma_1^2, \ldots, \sigma_K^2)$
- We can't differentiate through random sampling ($z_i \sim \mathcal{N}(\mu_i, \Sigma_i)$, but we can apply the ***reparameterization trick:***

$$\mathrm{z_i} = \mu_i + \sigma_i \epsilon_i$$

where $\epsilon_i \sim \mathcal{N}(0,1)$

原课件第 47 页：从 VAE 到序列潜变量模型

原页称 VAE 对每个样本采用相同固定先验 $z \sim \mathcal{N}(0, I)$；世界模型的未来取决于过去位置和动作，因此将固定先验替换为学得的 $p(z_t \mid z_{t-1}, a_{t-1})$。其余部分包括给出后验的编码器、重

建输入的解码器以及两者之间的 KL；先验现在就是转移模型。这里是课件对特定构造的概括，固定先验并非所有 VAE 或世界模型的普遍限制。

原课件第 48 页：循环状态空间模型

原图按时间排列观测 o、随机状态 z、确定性状态 h 与动作 a。从 o 出发的蓝线表示帧进入后验 $q(z \mid h, o)$；从 h 出发的虚线表示不观察该帧的先验 $p(z \mid h)$。KL 拉近先验与后验，想象时运行的是先验。

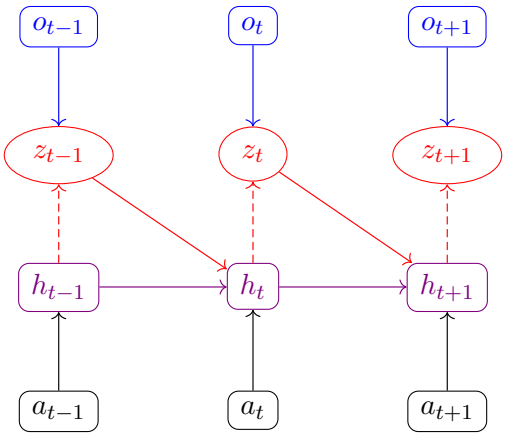

图中动作与确定性状态的时间下标按原图同列保留，不静默改成另一种递推索引约定。

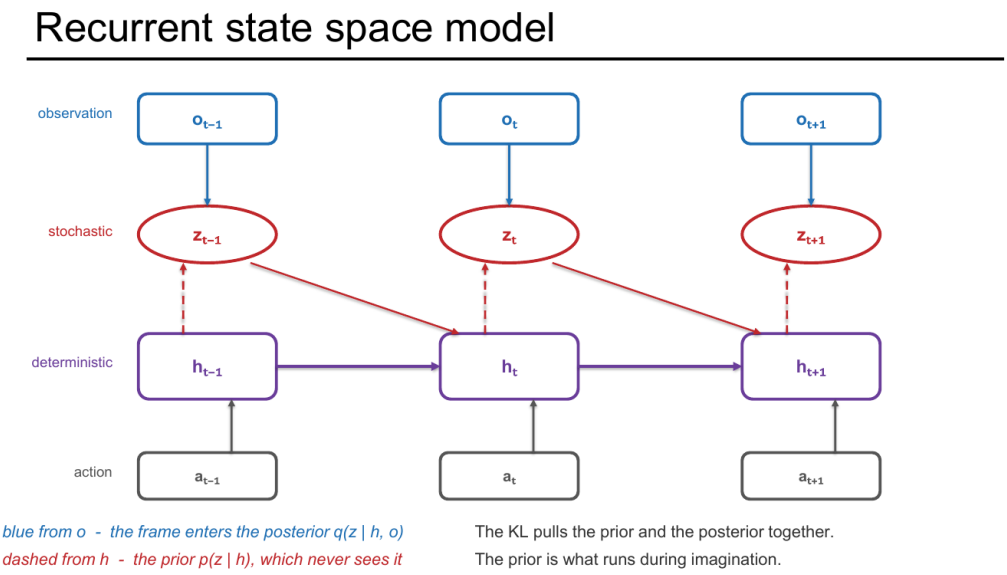

原课件第 49 页：损失包含什么

- 重建：解码器须从状态重建帧。
- 奖励：状态上的一个预测头必须预测 r_t，否则状态可以丢弃任务关心的全部内容。
- KL：位于看到帧的后验 $q(z_t \mid h_t, o_t)$ 与未看到帧的先验 $p(z_t \mid h_t)$ 之间。
- 原页称在 VAE 中 KL 只是正则项，而这里是先验的全部训练信号，因为先验只在损失的这一处出现；写出来是给定动作的观测序列 ELBO。该说法的模型和梯度依赖范围待审。

原课件第 50 页：在想象中学习

图中真实经验 o_0, o_1, o_2 编码为 z_0, z_1, z_2，之后行动者 π 提议动作产生想象状态 $\hat{z}_3, \ldots, \hat{z}_6$；奖励和价值头 $\hat{r}, \hat{v}$ 对轨迹评分。

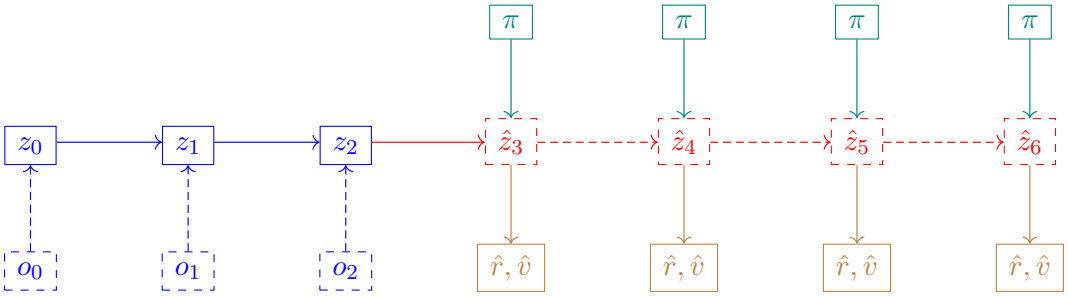

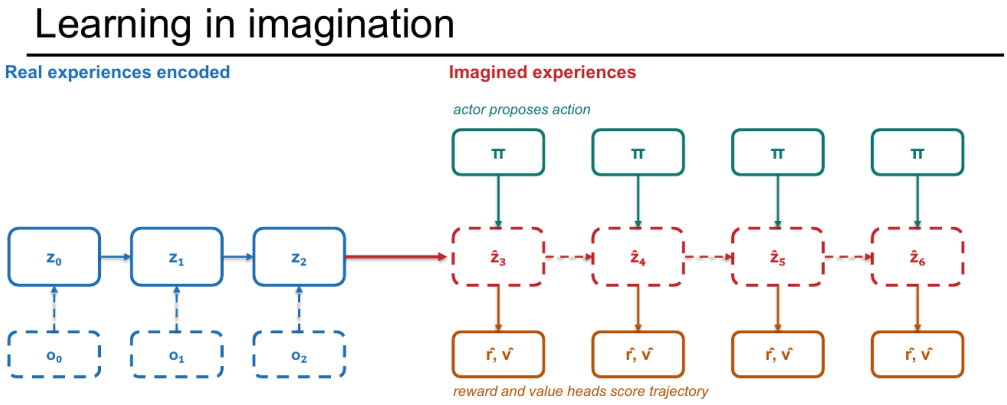

原课件第 51 页：相同组件的两种连接方式

原图比较 RNN 与 MDN，以及 RNN 与 SSM 两种结构；后一结构损失写为 $\mathcal{L} = \mathcal{L}_{\text{pred}} + \mathcal{L}_{\text{dyn}} + \mathcal{L}_{\text{rep}}$。来源：arXiv:2606.12783, Fig. 5。与第 2 份第 15 页重复；下方复用其已保存的可编辑节点、损失连线和符号，原截图仍保留。

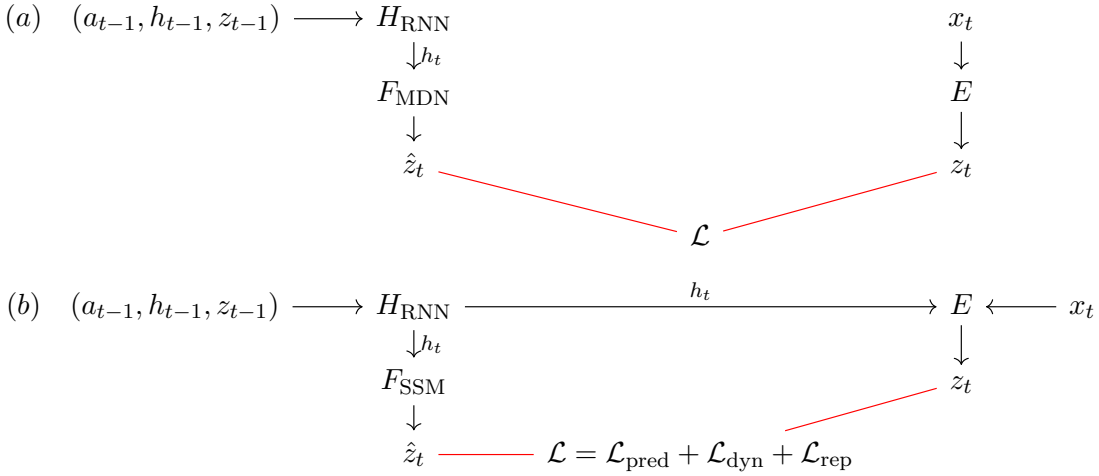

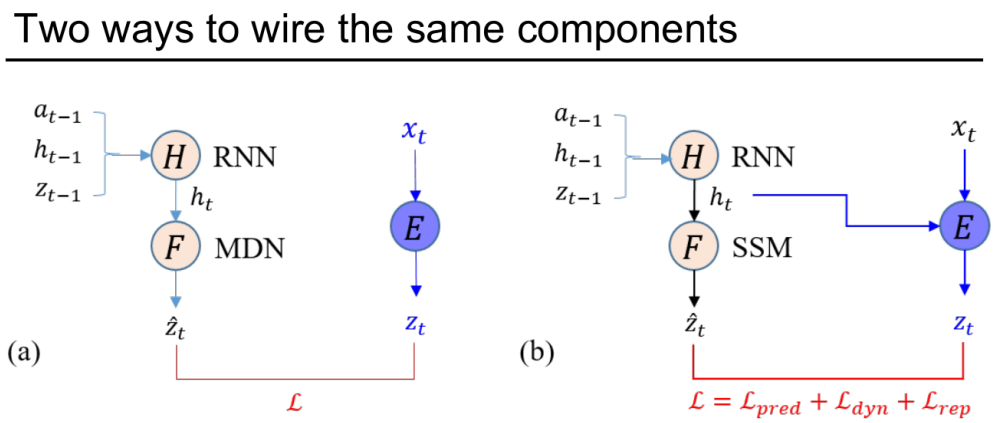

arXiv:2606.12783, Fig. 5

原课件第 52 页：哪些地方会出问题

- 模型利用：行动者针对模型优化，因此会找到模型错误的位置。
- 误差累积：因此使用较短时域，每次展开从真实状态重新开始。
- 潜变量可能丢掉重要信息：重建损失可能关注大而亮的像素，而非小物体。
- 奖励稀疏：如果奖励头从未见过奖励，就没有信号推动状态编码导致奖励的因素。

这些均为原课件对所述方法的概括，适用范围待审。

原课件第 53 页：提纲

接下来讨论应用。

原课件第 54 页：应用——机器人运动的自适应策略

原图展示 RMA 在多种困难环境下的表现。图注称：机器人在沙地、泥地、徒步小径、高草和土堆的全部试验中均成功行走；沿徒步小径下楼的试验成功率为 70%，穿越水泥堆和卵石堆的试验成功率为 80%。训练中未见过不稳定或下陷地面、阻挡性植被和楼梯；所有部署结果使用同一策略，没有仿真校准或真实世界微调。视频网址见原图。来源：A. Kumar et al., *RMA: Rapid Motor Adaptation for Legged Robots*, RSS 2021。

Application: Adaptive policies for robot locomotion

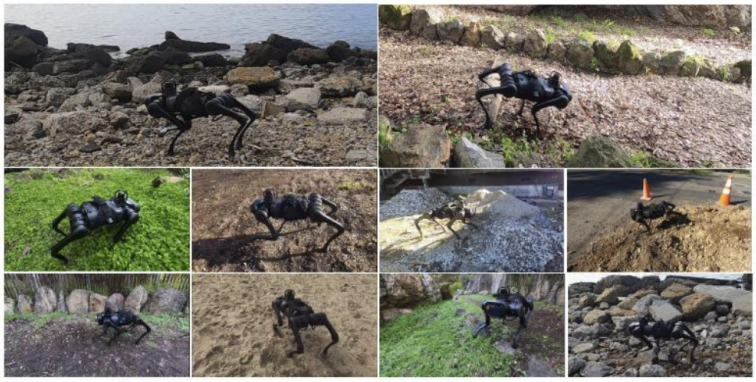

Fig. 1: We demonstrate the performance of RMA on several challenging environments. The robot is successfully able to walk on sand, mud, hiking trails, tall grass and dirt pile without a single failure in all our trials. The robot was successful in 70% of the trials when walking down stairs along a hiking trail, and succeeded in 80% of the trials when walking across a cement pile and a pile of pebbles. The robot achieves this high success rate despite never having seen unstable or sinking ground, obstructive vegetation or stairs during training. All deployment results are with the same policy without any simulation calibration, or real-world fine-tuning. Videos at https://ashish-kmr.github.io/rma-legged-robots/

A. Kumar et al. RMA: Rapid Motor Adaptation for Legged Robots. RSS 2021
Method video

原课件第 55 页：RMA 训练与部署

图分为仿真训练和部署。训练阶段一将质量、质心、摩擦、地形高度、电机强度等环境因素 e_t 送入环境因素编码器 μ 得到 z_t，再与状态 x_t、前一动作 a_{t-1} 一起输入基础策略 π，输出 a_t 作用于物理仿真。阶段二由适应模块 ϕ 根据图中标为 $(x_{t-51}, a_{t-51}), \ldots, (x_{t-1}, a_{t-1})$ 的历史估计 $\hat{z}_t$，回归阶段一的 z_t，再与 x_t, a_{t-1} 送入基础策略。红色标记可训练模块。部署时图中历史写为 $(x_{t-50}, a_{t-51}), \ldots, (x_t, a_{t-1})$；适应模块以 10 Hz、基础策略以 100 Hz 运行，输出 a_t 驱动机器人。两个阶段的历史索引差异经本轮原页高分辨率作者读回后照图保留，不用一致性假设改写。来源同上一页。A：仿真训练，阶段一（上）及阶段二（下）；红色模块可训练。

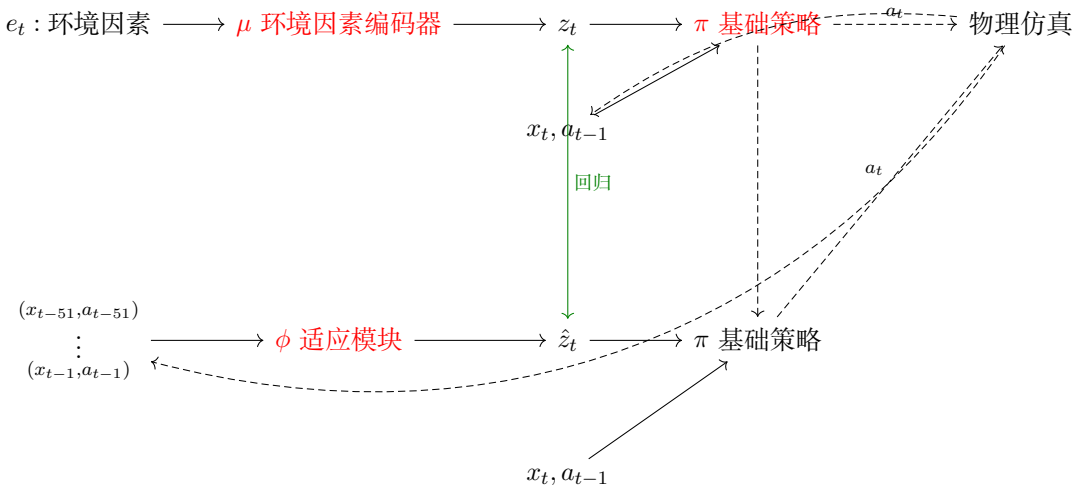

B：部署（历史首项原样保留）。

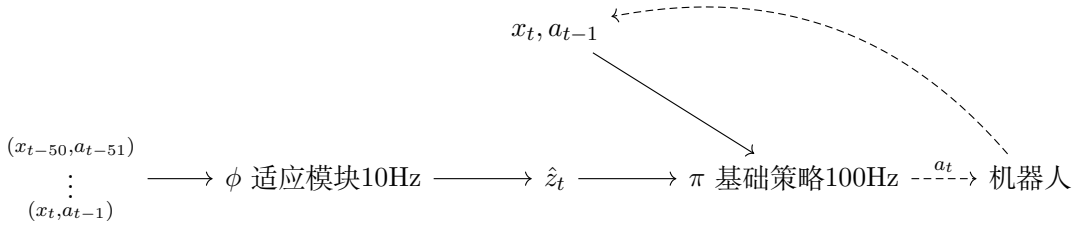

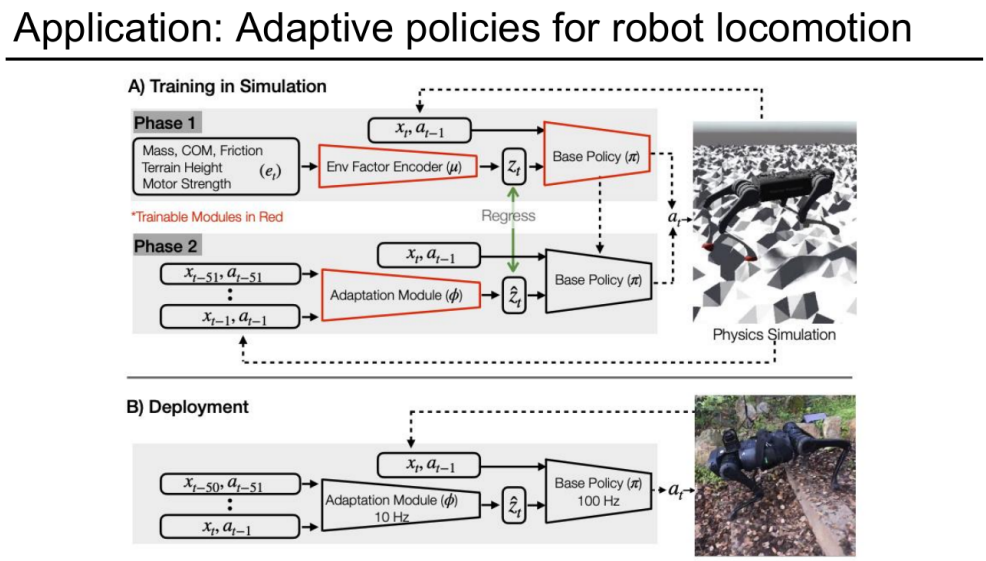

A. Kumar et al. RMA: Rapid Motor Adaptation for Legged Robots. RSS 2021
Method video

原课件第 56 页：视觉参与运动控制

图示第一阶段在仿真中用特权信息进行强化学习，第二阶段在仿真中通过监督学习利用机载感知；对比 RMA 与单体架构。图中 m_t 为扫描点，e_t 为环境参数，x_t 为本体感知，d_t 为自我中心深度，a_t 为目标动作。图上复制、冻结、初始化及回归关系另作可编辑重建；原图用于图像细节与连线布局对照。来源：A. Agarwal et al., *Legged Locomotion in Challenging Terrains using Egocentric Vision*, CoRL 2022。RMA：阶段一在仿真中用特权信息强化学习；阶段二在仿真中监督学习机载感知。

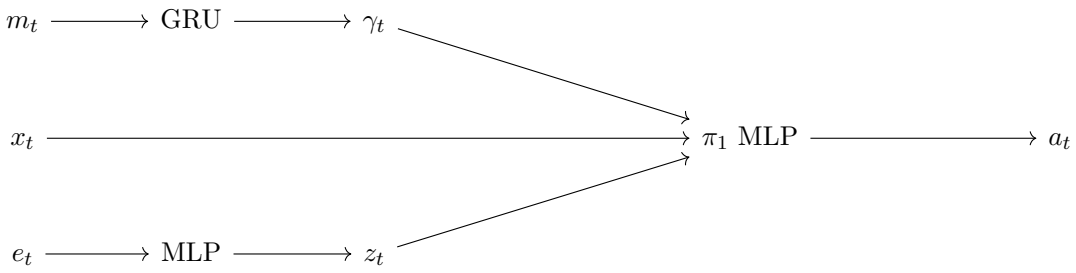

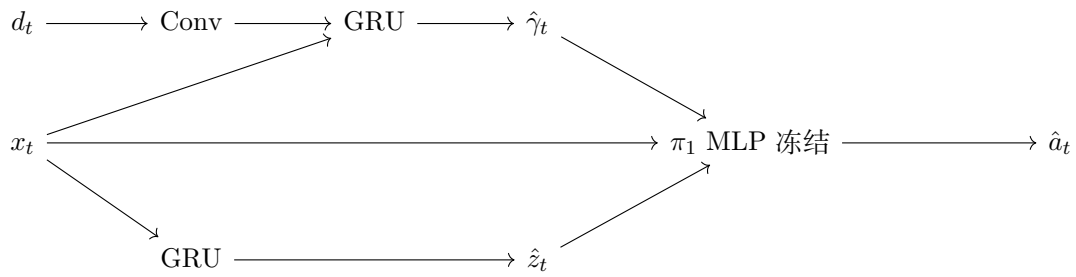

上图两个阶段之间的关系单列如下；节点名称与上图相同：

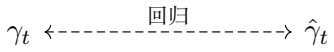

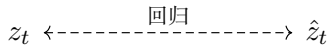

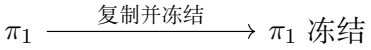

单体架构：上为阶段一，下为阶段二。

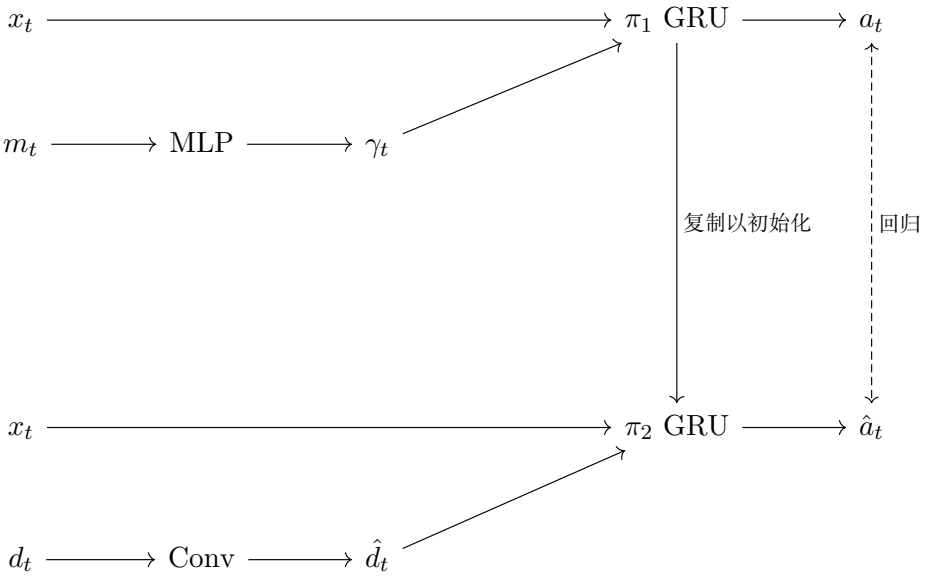

特权感知：扫描点 m_t、环境参数 e_t（质量、摩擦等）；机载感知：本体感知 x_t、自我中心深度 d_t；目标动作 a_t。原照片标示 Simulation（仿真）、Robot（机器人）、Scandots（扫描点）与 Egocentric Depth（自我中心深度）。

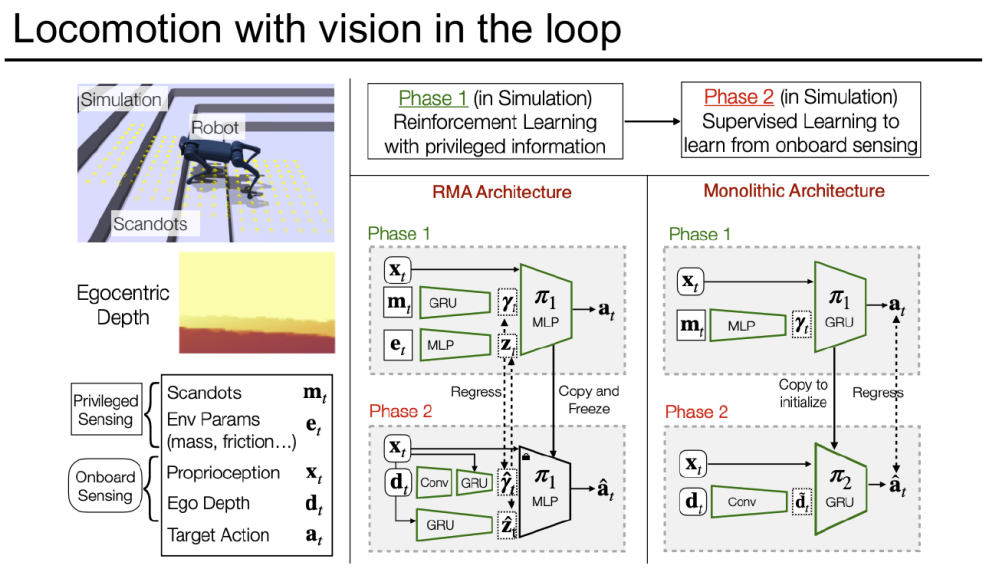

A. Agarwal et al. Legged Locomotion in Challenging Terrains using Egocentric Vision. CoRL 2022

原课件第 57 页：应用——从视频学习技能

图注：模拟角色通过模仿人类示范视频学习高度动态的技能。左：人形角色在不规则地形上完成侧手翻 B；右：后空翻 A 重定向至模拟 Atlas 机器人。来源：X. B. Peng et al., *SFV: Reinforcement Learning of Physical Skills from Videos*, SIGGRAPH Asia 2018；原页另有视频链接。

Fig. 1. Simulated characters performing highly dynamic skills learned by imitating video clips of human demonstrations. **Left:** Humanoid performing cartwheel B on irregular terrain. **Right:** Backflip A retargeted to a simulated Atlas robot.

Video

X. B. Peng et al. SFV: Reinforcement Learning of Physical Skills from Videos. SIGGRAPH Asia 2018

原课件第 58 页：从视频学习技能的流程

图示视频经姿态估计、姿态序列、运动重建得到参考运动；参考运动与角色送入强化学习运动模仿，得到策略 π。来源同上一页。

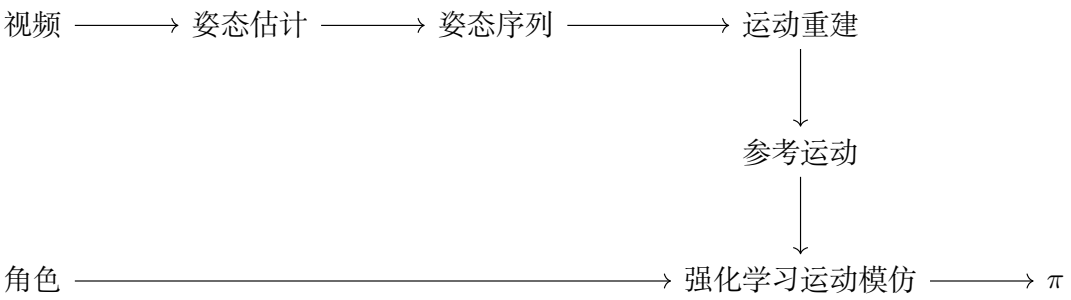

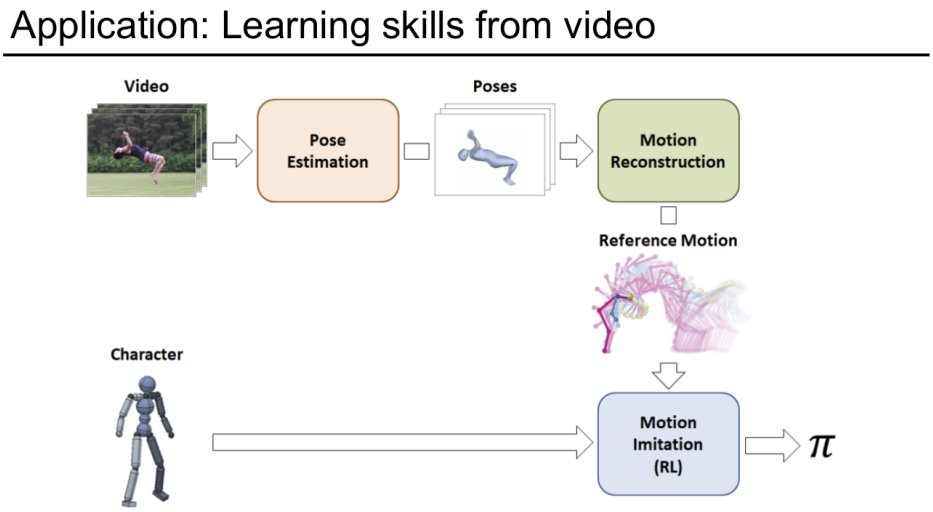

X. B. Peng et al. SFV: Reinforcement Learning of Physical Skills from Videos. SIGGRAPH Asia 2018

原课件第 59 页：运动估计细节

每帧同时使用 OpenPose 二维姿态估计器和 Human Mesh Recovery（HMR）三维姿态估计器。图中自上而下为视频帧、三维姿态预测、二维姿态预测。

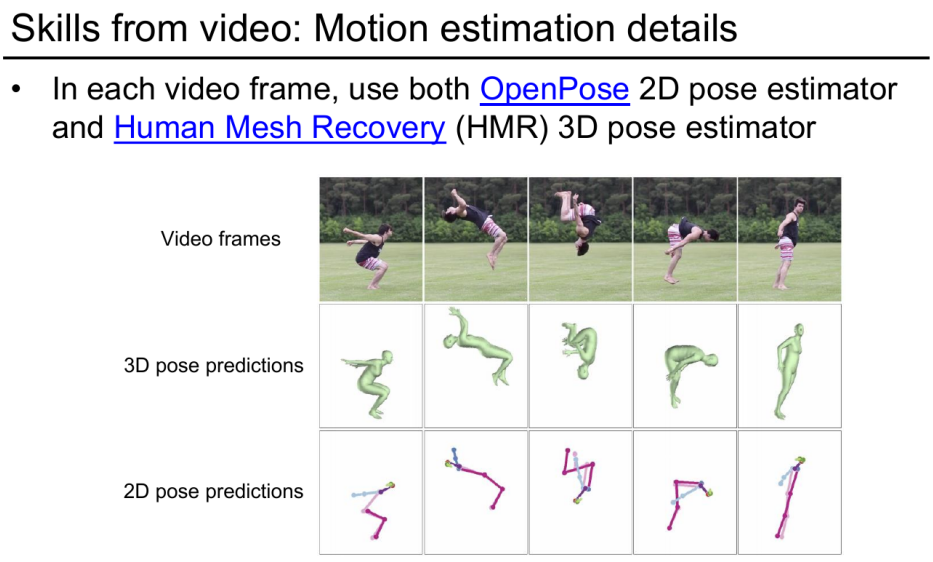

原课件第 60 页：运动重建

优化轨迹，使其与逐帧二维、三维预测一致并保持平滑。图注称，上行为视频，中行为运动重建前三维姿态估计器的原始预测，下行为重建后结果；利用二维估计信息与相邻帧时间一致性，可以修正三维估计器的错误预测。图示侧手翻 A 和前空翻。

Skills from video: Motion estimation details

- In each video frame, use both OpenPose 2D pose estimator and Human Mesh Recovery (HMR) 3D pose estimator
- Motion reconstruction: optimize trajectory consistent with per-frame 2D and 3D predictions while maintaining smoothness

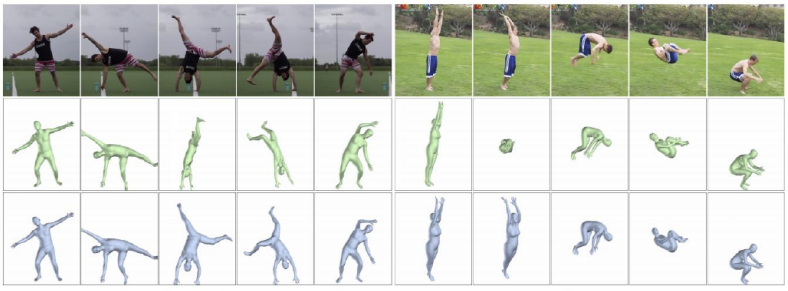

(a) Cartwheel A (b) Frontflip

Fig. 11. 3D pose predictions before and after motion reconstruction. **Top:** Video. **Middle:** Raw predictions from the 3D pose estimator before motion reconstruction. **Bottom:** After motion reconstruction. The motion reconstruction process is able to fix erroneous predictions from the 3D pose estimator by taking advantage of the information from the 2D pose estimator and temporal consistency between adjacent frames.

原课件第 61 页：运动模仿

寻找策略，使模拟运动复现参考运动。图示前空翻和手翻 A 的人类视频、重建角色与模拟角色序列。

Skills from video: Motion imitation details

- Find policy to encourage simulated motion to reproduce reference motion

(a) Frontflip (b) Handspring A

原课件第 62 页：运动模仿细节

- 状态（身体构型）：各身体部分相对于根部的位置、旋转、线速度和角速度，以及动作阶段（起点为 0，终点为 1）。
- 动作：每个关节的目标旋转，共 36 维。
- 转移模型或动力学：来自基于物理的仿真。
- 模仿奖励函数：姿态、速度、末端执行器和质心误差项之和。
- 策略通过 PPO 寻找；需要策略网络（两层全连接，输出表示动作高斯分布的参数）和价值网络。自适应状态初始化将初始状态分布作为另一策略来学习。

原课件第 63 页：从视频学习技能的结果

原图左侧为迁移到不同环境的技能：依次是在坡面上后空翻 A、跨间隙侧手翻 B、推箱子下坡及上坡；右侧给定目标图像，运动补全方法预测图中人物可能的动作。原页有视频链接。

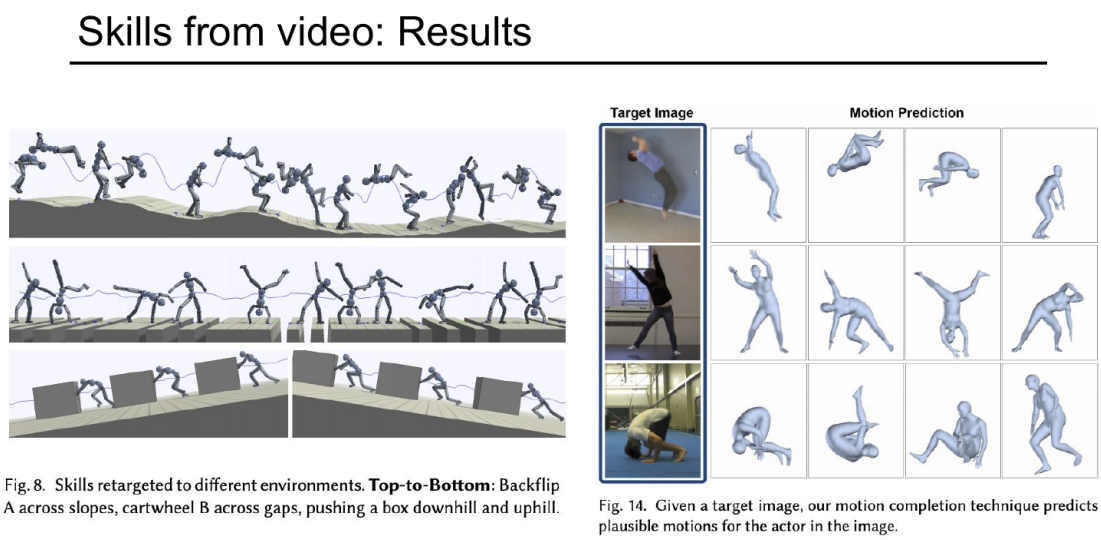

Fig. 8. Skills retargeted to different environments. **Top-to-Bottom**: Backflip A across slopes, cartwheel B across gaps, pushing a box downhill and uphill.

Fig. 14. Given a target image, our motion completion technique predicts plausible motions for the actor in the image.

Video

原课件第 64 页：附录 A——关于 VAE 的补充

原页仅有附录标题。

原课件第 65 页：自编码器

如何学习特征表示？训练特征使之可以重建原始数据；“自编码”即编码自身。原图依次标出输入数据 x、编码器、特征 z、解码器、重建输入 $\hat{x}$。

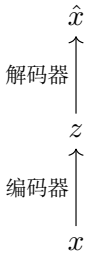

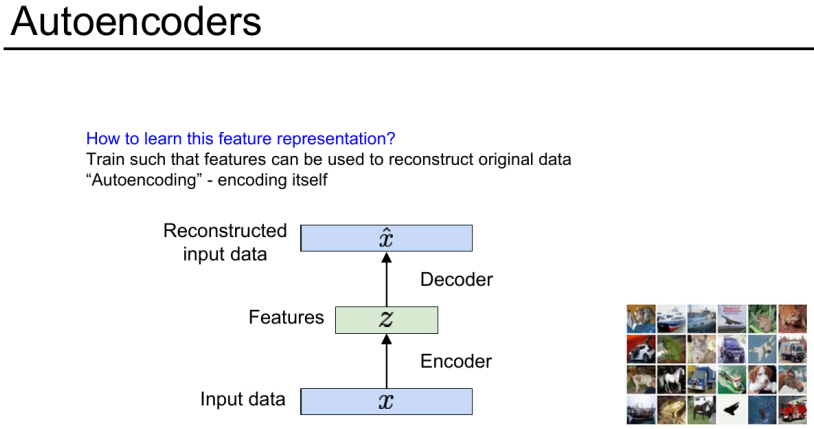

原课件第 66 页：变分自编码器

原页再次写出

$$p_\theta(x) = \log \int_z p_\theta(z) p_\theta(x \mid z)\, dz.$$

课件称模型只在 X 的低维子流形上生成，提出定义带噪声的观测模型，例如 $p(x \mid z) = \mathcal{N}(x; G_\theta(z), \eta I)$，其中 G_θ 是参数为 θ 的解码器函数。上述首式左侧缺少对数，按原文保留并记录疑点。

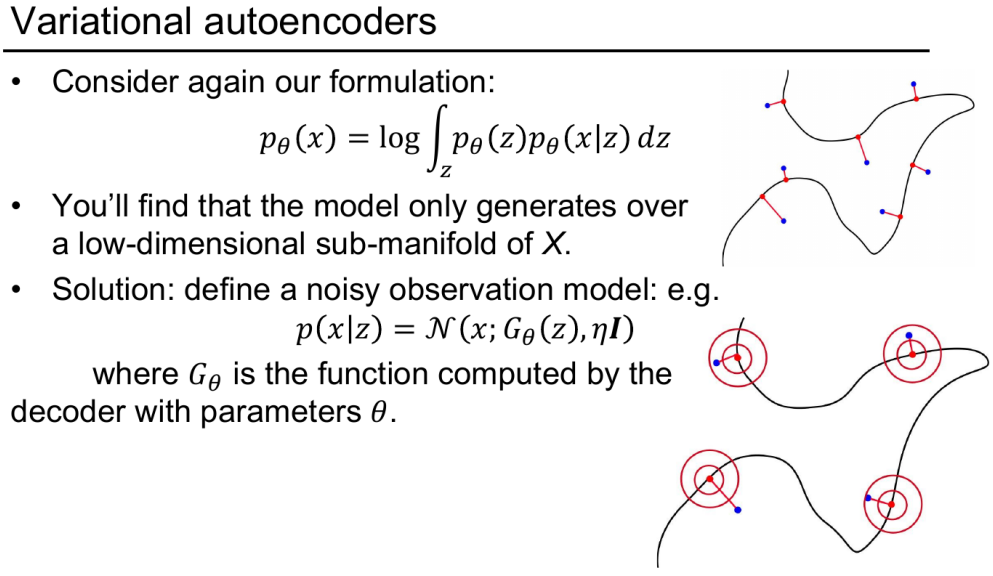

原课件第 67 页：变分近似

原页给出 $p_\theta(x)=\int_z p_\theta(z)p_\theta(x\mid z)$，但未显示积分微分。课件称解码器是复杂神经网络，难望得到闭式解；因此改为最大化 $\log p(x)$ 的下界，并询问可用什么技术构造下界。

原课件第 68 页：重建项

原页先考虑 $\mathbb{E}_q[\log p(x\mid z)]$，对高斯观测模型写出：

$$\begin{aligned}\log p(x\mid z) &= \mathcal{N}(x;G_\theta(z);\eta I)\\ &= \log\left[\frac{1}{(2\pi\eta)^{1/2}}e^{-\frac{1}{2\eta}\|x-G_\theta(z)\|^2}\right]\\ &= -\frac{1}{2\eta}\|x-G_\theta(z)\|^2+\text{const.}\end{aligned}$$

课件称这给出从 z 重建 x 的误差项。首行将对数密度写成密度，归一化因子对多维 x 的维数依赖也未体现；均保留原式并标记。

Reconstruction term

- We'll first look at $\mathbb{E}_q[\log p(x|z)]$
- As we said before, we can assume some simple observation model (let's use a Gaussian). Then:

$$\begin{aligned}\log p(x|z) &= \mathcal{N}(x;G_\theta(z);\eta I)\\ &= \log\left[\frac{1}{(2\pi\eta)^{\frac{1}{2}}}e^{\left(-\frac{1}{2\eta}||x-G_\theta(z)||^2\right)}\right]\\ &= -\frac{1}{2\eta}\left||x-G_\theta(z)\right||^2+const\end{aligned}$$

- So one of our terms is just the **reconstruction term** – i.e. the error in reconstructing x from z.

原课件第 69 页：另一项是什么？

原页提问如何理解 $\mathbb{E}_q[\log(p(z)/q(z))]$；参见第 45 页 KL 散度。

原课件第 70 页：变分下界

原页给出

$$\log p(x)\ge\mathcal{F}(\theta,q)=\mathbb{E}_q[\log p(x\mid z)]-D_{\mathrm{KL}}(q\|p),$$
$$\log p(x)-\mathcal{F}(\theta,q)=D_{\mathrm{KL}}(q(z)\|p(z\mid x)).$$

选择 q 使下界尽可能紧，也就是使其尽可能接近后验 $p(z\mid x)$。**译注：**该有限 KL 间隙恒等式需 $p(x)>0$、q 相对于后验 $p(z\mid x)$ 绝对连续且相关对数期望有定义；若支撑不匹配或项发散，不可随意将无穷项相减。把第 44 页的重要性形式写成对 q 的精确期望还需覆盖原联合密度积分的支撑。

原课件第 71 页：摊销

将推断网络与解码器组合后，结构近似普通自编码器，推断网络类似编码器，因此称为变分自编码器。编码器和解码器参数通过一次普通反向传播更新。原页称 KL 项通过鼓励 z 更随机来正则化表示；该直观说法取决于先验及参数化，须结合具体 KL 核查。图中 x 经网络得到 $\mu, \log\sigma$，与噪声 ϵ 一起产生 z，标记 $q(z \mid x)$。

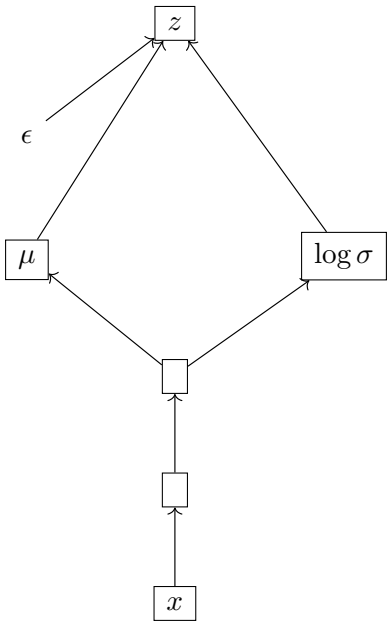

两参数支路旁原标 $q(z \mid x)$；两个隐层方框不额外命名。

Amortization

- Combining this with the decoder network, we see the structure closely resembles an ordinary autoencoder. The inference net is like an encoder.
- Hence, this architecture is known as a variational autoencoder (VAE).
- The parameters of both the encoder and decoder networks are updated using a single pass of ordinary backprop.
- The KL term regularizes the representation by encouraging z to be more stochastic.