因果推断要素

Elements of Causal Inference: Foundations and Learning Algorithms

Jonas Peters, Dominik Janzing, Bernhard Schölkopf

2017 年版 · MIT Press · 2017
Model: gpt-6.1-terra; gpt-6.1-sol
审核：曹溪能
Updated: 2026-11-06

原版版权页

© 2017 Massachusetts Institute of Technology

本作品依据 Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International 许可（知识共享署名—非商业性使用—禁止演绎 4.0 国际许可）向公众授权：http://creativecommons.org/licenses/by-nc-nd/4.0/.

除上述知识共享许可授权的范围外，保留所有权利. 任何未经上述许可授权的复制或其他使用，无论使用何种电子或机械手段（包括但不限于影印、公开分发、在线展示以及数字信息存储和检索），均须取得出版者的书面许可.

本书由作者使用 LaTeX 排版.

在美利坚合众国印刷、装订.

美国国会图书馆出版物编目数据：

姓名：Peters, Jonas；Janzing, Dominik；Schölkopf, Bernhard.

书名：Elements of causal inference : foundations and learning algorithms / Jonas Peters, Dominik Janzing, and Bernhard Schölkopf.

出版信息：Cambridge, MA : MIT Press, 2017. 丛书：Adaptive computation and machine learning series. 含参考文献和索引.

标识符：LCCN 2017020087；ISBN 9780262037310（精装：无酸纸）.

主题（LCSH）：Machine learning；Logic, Symbolic and mathematical；Causation；Inference；Computer algorithms.

分类：LCC Q325.5 .P48 2017；DDC 006.3/1–dc23.

美国国会图书馆记录：https://lccn.loc.gov/2017020087.

10 9 8 7 6 5 4 3 2 1

译本说明

本译稿完整覆盖冻结的 2017 版 289 页 PDF 中可见的正文、附录、习题、书目、索引及丛书书目，为本地作者稿，待独立审校与主控验收. 源书未附习题解答；不另行补造. 原书页码和译本页码不同，原索引明确保留原版印刷页码. 所有原文疑点均保留原式，并在相邻位置作译注；这些注释不代表作者原意已确认.

实际模型历史中可核实 2026-11-04/05 续译为 gpt-6.1-terra/high，2026-11-06 恢复续译、整合与作者检查为 gpt-6.1-sol/high；更早初译模型未可靠确认. 封面固定字段“审核：曹溪能”为项目版式要求，不表示本人已完成审阅. 公开分发前须核实许可或取得授权.

原书丛书：Adaptive Computation and Machine Learning（自适应计算与机器学习）. 主编 Francis Bach；副主编 Christopher Bishop、David Heckerman、Michael Jordan、Michael Kearns. 原书完整丛书书目见书末.

献给所有乐于追求因果洞见的人.

目录

前言 vii

记号与术语 x

第 1 章 统计模型与因果模型 1

1.1 概率论与统计学 . . . 1
1.2 学习理论 . . . 2
1.3 因果建模与学习 . . . 3
1.4 两个例子 . . . 5
1.4.1 模式识别 . . . 5
1.4.2 基因扰动 . . . 7

第 2 章 因果推断的假设 9

2.1 独立机制原则 . . . 9
2.2 历史注记 . . . 13
2.3 因果模型背后的物理结构 . . . 17
2.3.1 时间的作用 . . . 17
2.3.2 物理定律 . . . 18
2.3.3 有环赋值 . . . 18
2.3.4 干预的可行性 . . . 19
2.3.5 原因与机制独立性及热力学时间箭头 . . . 19

第 3 章 因果对模型 21

3.1 结构因果模型 . . . 21
3.2 干预 . . . 21
3.3 反事实 . . . 23
3.4 结构因果模型的规范表示 . . . 24
3.5 习题 . . . 25

第 4 章 学习因果对模型 27

4.1 结构可识别性 . . . 27
4.1.1 为何需要额外假设 . . . 27
4.1.2 假设类型概览 . . . 28
4.1.3 具有非高斯加性噪声的线性模型 . . . 30
4.1.4 非线性加性噪声模型 . . . 31
4.1.5 离散加性噪声模型 . . . 33
4.1.6 后非线性模型 . . . 34
4.1.7 信息几何因果推断 . . . 35
4.1.8 迹方法 . . . 36
4.1.9 作为可能基础的算法信息论 . . . 38
4.2 结构识别方法 . . . 40
4.2.1 加性噪声模型 . . . 40

4.2.2 信息几何因果推断 . . . 43
4.2.3 迹方法 . . . 44
4.2.4 监督学习方法 . . . 44
4.3 习题 . . . 45

第 5 章 与机器学习的联系，I **48**
5.1 半监督学习 . . . 48
5.1.1 SSL 与因果方向 . . . 48
5.1.2 关于因果方向 SSL 的一个注记 . . . 49
5.2 协变量偏移 . . . 53
5.3 习题 . . . 55

第 6 章 多变量因果模型 **56**
6.1 图论术语 . . . 56
6.2 结构因果模型 . . . 57
6.3 干预 . . . 61
6.4 反事实 . . . 66
6.5 Markov 性、忠实性与因果极小性 . . . 69
6.5.1 Markov 性 . . . 69
6.5.2 因果图模型 . . . 72
6.5.3 忠实性与因果极小性 . . . 73
6.6 通过协变量调整计算干预分布 . . . 75
6.7 *do* 演算 . . . 81
6.8 因果模型的等价性与可证伪性 . . . 82
6.9 潜在结果 . . . 84
6.9.1 定义与例子 . . . 84
6.9.2 潜在结果与 SCM 的关系 . . . 85
6.10 联系单个对象的广义结构因果模型 . . . 87
6.11 条件分布的算法独立性 . . . 88
6.12 习题 . . . 90

第 7 章 学习多变量因果模型 **92**
7.1 结构可识别性 . . . 92
7.1.1 忠实性 . . . 92
7.1.2 加性噪声模型 . . . 93
7.1.3 等误差方差的线性高斯模型 . . . 94
7.1.4 线性非高斯无环模型 . . . 94
7.1.5 非线性高斯加性噪声模型 . . . 95
7.1.6 观测数据与实验数据 . . . 95
7.2 结构识别的方法 . . . 97
7.2.1 基于独立性的方法 . . . 97
7.2.2 基于评分的方法 . . . 101

7.2.3 加性噪声模型 . . . 103
7.2.4 已知因果顺序 . . . 103
7.2.5 观测数据与实验数据 . . . 104
7.3 习题 . . . 105

第 8 章 与机器学习的联系，II **106**
8.1 半同胞回归 . . . 106
8.2 因果推断与分幕式强化学习 . . . 107
8.2.1 逆概率加权 . . . 108
8.2.2 分幕式强化学习 . . . 109
8.2.3 二十一点中的状态简化 . . . 110
8.2.4 广告投放中的改进加权 . . . 112
8.3 领域适应 . . . 113
8.4 习题 . . . 115

第 9 章 隐藏变量 **116**
9.1 干预充分性 . . . 116
9.2 Simpson 悖论 . . . 118
9.3 工具变量 . . . 118
9.4 条件独立性与图形表示 . . . 120
9.4.1 图 . . . 121
9.4.2 快速因果推断 . . . 123
9.5 条件独立之外的约束 . . . 123
9.5.1 Verma 约束 . . . 124
9.5.2 不等式约束 . . . 124
9.5.3 基于协方差的约束 . . . 126
9.5.4 加性噪声模型 . . . 128
9.5.5 检测低复杂度混杂因素 . . . 129
9.5.6 不同环境 . . . 132
9.6 习题 . . . 132

第 10 章 时间序列 **134**
10.1 预备知识与术语 . . . 134
10.2 结构因果模型与干预 . . . 136
10.2.1 次采样 . . . 136
10.3 学习因果时间序列模型 . . . 137
10.3.1 Markov 条件与忠实性 . . . 137
10.3.2 有些因果结论不需要忠实性 . . . 138
10.3.3 Granger 因果 . . . 138
10.3.4 受限函数类模型 . . . 142
10.3.5 谱独立判据 . . . 142
10.4 动态因果建模 . . . 143

10.5 习题 144

附录 A 概率与统计补充 145

A.1 基本定义 145
A.2 独立与条件独立检验 147
A.3 函数类的容量 149

附录 B 因果顺序与邻接矩阵 151

附录 C 证明 153

C.1 定理 4.2 的证明 153
C.2 命题 6.3 的证明 153
C.3 注 6.6 的证明 154
C.4 命题 6.13 的证明 154
C.5 命题 6.14 的证明 155
C.6 命题 6.36 的证明 155
C.7 命题 6.48 的证明 156
C.8 命题 6.49 的证明 156
C.9 命题 7.1 的证明 157
C.10 命题 7.4 的证明 157
C.11 命题 8.1 的证明 158
C.12 命题 8.2 的证明 158
C.13 命题 9.3 的证明 159
C.14 定理 10.3 的证明 159
C.15 定理 10.4 的证明 159

参考文献 160

原书索引 187

原书丛书书目 192

术语索引 194

前言

因果性是一个引人入胜的研究课题. 它的数学化只是相对近来才开始，许多概念问题仍在争论之中，而且争论往往十分激烈.

本书总结了我们十年来探索因果性所取得的成果；但也有人研究这一问题的时间比我们长得多，而且已有关于因果性的著作，包括 Pearl [2009]、Spirtes 等 [2000] 以及 Imbens 和 Rubin [2015] 的综合性论述. 我们希望本书能够从两个方面补充已有工作.

首先，本书偏重于因果性的一个子问题，它可以被视为既最基础又最不现实的问题，即因果问题：所分析的系统只包含两个可观测量. 过去十年间，我们对这一问题作了较为细致的研究. 本书介绍了其中的许多工作，并试图将它们放入一个更广阔的背景；在我们看来，这一背景对于有选择地深入理解因果性问题至关重要. 按章节顺序先学习二元情形或许很有启发，但也可以直接从多元章节开始阅读，参见图 I.

其次，我们的论述受到机器学习和计算统计领域的启发与影响. 我们关心这些领域的方法如何帮助推断因果结构，更关心因果推理能否启发我们如何开展机器学习. 我们认为，要理解机器学习中一些最深刻的未解问题，最好不要从由概率分布描述的随机试验出发，而应考察该分布背后的因果结构.

我们力求系统地介绍这一主题，使熟悉概率论和统计学或机器学习基础的读者能够理解（为求完整，附录 A.1 和 A.2 概述了最重要的概念）.

尽管我们的工作建立在以 Pearl [2009] 和 Spirtes 等 [2000] 为代表的因果图方法之上，主题的选择仍受我们个人偏好的影响. 为使本书易于阅读并聚焦于概念问题，我们不得不遗憾地对若干重要因果问题着墨甚少，无论是特定情形下更深入的理论见解，还是具有实际重要性的各种方法，都是如此. 对于一些最明显的遗漏，我们尽力提供了相关文献，但仍可能遗漏重要主题.

本书有若干不足. 有些不足源于这一领域本身，例如理论结果往往限于数据无限的情形. 虽然我们也提供有限数据情形的算法和方法，但并未讨论这些方法的统计性质. 此外，我们在一些地方忽略测度论问题，常常假设密度存在. 我们认为这些问题都既重要又有趣，但为了保持篇幅简短、便于广泛读者阅读，作出了这些取舍.

还有一点需要说明. 计算因果性方法仍处于起步阶段，尤其是从数据中学习因果结构仅在相当有限的情形下可行. 我们尽可能给出具体算法，但也深知许多因果推断问题比典型的机器学习问题更困难，因此不能保证这些算法能够解决读者的问题. 请不要因此感到气馁——因果学习是一个引人入胜的主题，我们希望本书能促使你开始从事这一研究.

没有许多人的支持，我们无法完成本书. 我们衷心感谢 Oberwolfach 数学研究所支持三位作者参加 Research in Pairs 驻留项目，本书的很大一部分就是在那期间写成的.

感谢 Michel Besserve、Peter Bühlmann、Rune Christiansen、Frederick Eberhardt、Jan Ernest、Philipp Geiger、Niels Richard Hansen、Alain Hauser、Biwei Huang、Marek Kaluba、Hansruedi Künsch、Steffen Lauritzen、Jan Lemeire、David Lopez-Paz、Marloes Maathuis、Nicolai Meinshausen、Søren Wengel Mogensen、Joris Mooij、Krikamol Muandet、Judea Pearl、Niklas Pfister、Thomas Richardson、Mateo Rojas-Carulla、Eleni Sgouritsa、Carl Johann Simon-Gabriel、Xiaohai Sun、Ilya Tolstikhin、Kun Zhang 和 Jakob Zscheischler 在本书写作期间提出许多有益意见并进行有趣的讨论. 其中，Joris

和 Kun 参与了本书所介绍的大量研究.

感谢卡尔斯鲁厄理工学院、苏黎世联邦理工学院和蒂宾根大学的学生校读本书早期版本，并提出许多富有启发性的问题.

最后，感谢匿名审稿人和 Westchester Publishing Services 的文字编辑团队提出有益意见，感谢 MIT Press 的工作人员，尤其是 Marie Lufkin Lee 和 Christine Bridget Savage，在整个过程中给予热情支持.

哥本哈根和蒂宾根，2017 年 8 月

Jonas Peters

Dominik Janzing

Bernhard Schölkopf

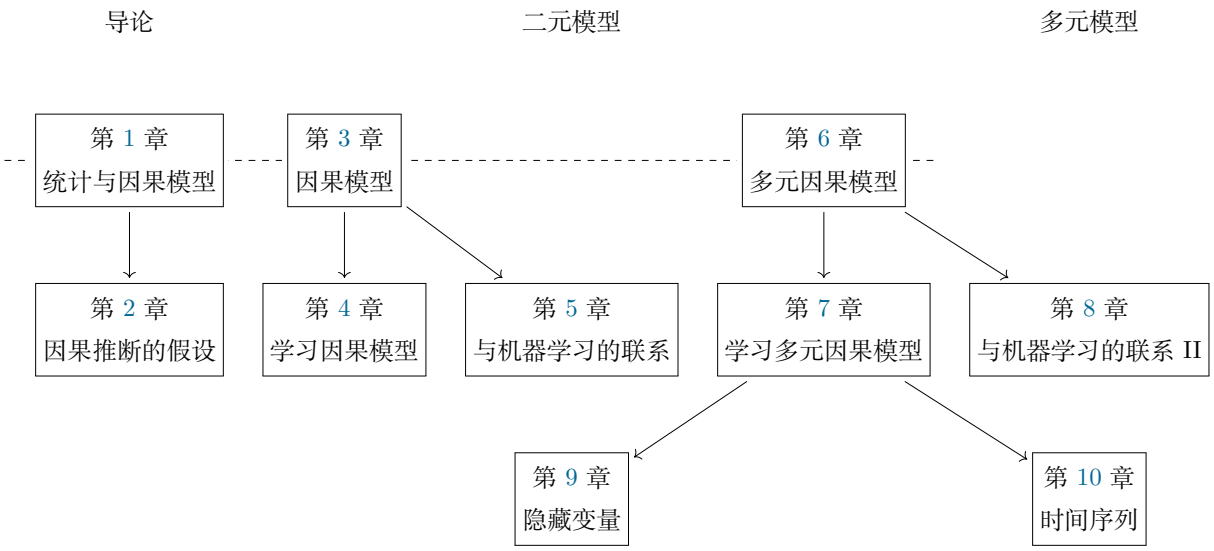


图 I: 本图展示章节之间较强的依赖关系（还有许多程度较弱的联系）. 我们建议读者从第 1、3 或 6 章开始阅读.

记号与术语

X, Y, Z	随机变量；噪声变量记作 $N, N_X, N_j, \ldots$
x	随机变量 X 的取值
P	概率测度
P_X	X 的概率分布
$X^1, \ldots, X^n \overset{\text{iid}}{\sim} P_X$	大小为 n 的独立同分布样本；样本指标通常记为 i
$P_{Y\|X=x}$	给定 $X = x$ 时 Y 的条件分布
$P_{Y\|X}$	对所有 x 的 $P_{Y\|X=x}$ 的集合；简称给定 X 时 Y 的条件分布
p	密度（概率质量函数或概率密度函数）
p_X	P_X 的密度
$p(x)$	P_X 的密度在点 x 处的值
$p(y \mid x)$	$P_{Y\|X=x}$ 的（条件）密度在 y 处的值
$\mathbb{E}[X]$	X 的期望
$\mathrm{var}[X]$	X 的方差
$\mathrm{cov}[X, Y]$	X, Y 的协方差
$X \perp\!\!\!\perp Y$	随机变量 X 和 Y 相互独立
$X \perp\!\!\!\perp Y \mid Z$	条件独立
$\mathbf{X} = (X_1, \ldots, X_d)$	长度为 d 的随机向量；维度指标通常记为 j
$\mathfrak{C}$	结构因果模型
$P_Y^{\mathfrak{C};\, do(X:=3)}$	干预分布
$P_Y^{\mathfrak{C}\mid Z=2, X=1;\, do(X:=3)}$	反事实分布
$\mathcal{G}$	图
$\mathbf{PA}_X^{\mathcal{G}}, \mathbf{DE}_X^{\mathcal{G}}, \mathbf{AN}_X^{\mathcal{G}}$	图 $\mathcal{G}$ 中节点 X 的父节点、后代和祖先

Chapter 1

统计模型与因果模型

借助统计学习，我们试图从观测数据推断随机变量之间依赖关系的性质. 例如，根据两个随机变量的一组联合观测样本，我们可以构建一个预测器：只要给出其中一个变量的新值，它就能对另一个变量给出良好的估计. 这种预测所依据的理论已相当成熟；尽管它适用于简单的情形，仍为理解如何从数据中学习提供了深刻见解. 出于两个原因，我们将在本章介绍其中的一些见解. 第一，这有助于我们认识到因果推断问题要困难得多：在因果推断中，底层模型不再是随机变量的一个固定联合分布，而是一个蕴含多个此类分布的结构. 第二，虽然因果估计的有限样本结果很少，但必须牢记，即使基本统计估计问题与纯统计学习中不会出现的因果问题相比显得较小，在转向更复杂的因果情形时，它们也并不会消失. 在上述基础上，本章还通过两个例子浅近地介绍因果性的基本概念，其中一个例子在机器学习领域广为人知.

1.1 概率论与统计学

概率论和统计学建立在随机试验或概率空间 $(\Omega, \mathcal{F}, P)$ 的模型之上. 这里，Ω 是一个集合（包含所有可能的结果），$\mathcal{F}$ 是事件 $A \subseteq \Omega$ 构成的集合，而 P 是为每个事件赋予概率的测度. 给定上述数学结构，概率论使我们能够对随机试验的结果进行推理. 相比之下，统计学习本质上处理的是逆问题：给定试验结果，我们希望据此推断底层数学结构的性质. 例如，假设我们观测到数据

$$(x_1, y_1), \ldots, (x_n, y_n), \tag{1.1}$$

其中 $x_i \in \mathcal{X}$ 是输入（有时称为协变量或案例），$y_i \in \mathcal{Y}$ 是输出（有时称为目标或标签）. 现在可以假设，每个 (x_i, y_i) $(i = 1, \ldots, n)$ 均由同一个未知随机试验独立地产生. 更确切地说，这样的模型假设观测值 $(x_1, y_1), \ldots, (x_n, y_n)$ 是随机变量 $(X_1, Y_1), \ldots, (X_n, Y_n)$ 的实现，这些随机变量独立同分布 (i.i.d.)，联合分布为 $P_{X,Y}$. 这里，X 和 Y 是分别取值于度量空间 $\mathcal{X}$ 和 $\mathcal{Y}$ 的随机变量.[1] 几乎所有统计学和机器学习都建立在独立同分布数据之上. 实践中，这一假设可能以多种方式被违背，例如分布发生偏移或系统中出现干预. 正如后文将看到的，其中一些情况与因果性有着错综复杂的联系.

我们可能对 $P_{X,Y}$ 的某些性质感兴趣，例如：

(i) 给定输入时输出的期望，$f(x) = \mathbb{E}[Y \mid X = x]$，称为回归，其中通常 $\mathcal{Y} = \mathbb{R}$；

(ii) 将每个 x 指派给概率较大的类别的二分类器，$f(x) = \operatorname{argmax}_{y \in \mathcal{Y}} P(Y = y \mid X = x)$，其中 $\mathcal{Y} = \{\pm 1\}$；

[1] 随机变量 X 是可测函数 $\Omega \to \mathcal{X}$，其中度量空间 $\mathcal{X}$ 配备 Borel σ-代数. X 在 $\mathcal{X}$ 上的分布 P_X 可由底层概率空间 $(\Omega, \mathcal{F}, P)$ 的测度 P 得到. 我们不必关心这个底层空间，而一般直接从随机变量的分布出发，假设随机试验直接给出从该分布采样得到的值.

(iii) $P_{X,Y}$ 的密度 $p_{X,Y}$（假设它存在）.

实践中，我们试图根据有限数据集估计这些性质，也就是根据样本 (1.1)，或等价地根据经验分布 $P^n_{X,Y}$ 来估计；该经验分布在每个观测值处放置权重相等的点质量.

这构成一个逆问题：我们希望根据对底层对象施加某种操作（在此为从未知分布中采样）而得到的观测，估计一个无法观测的对象（底层分布）的某种性质.

1.2 学习理论

现在假设，正如我们能从 $P_{X,Y}$ 得到 f 一样，我们利用经验分布推断经验估计 f^n. 事实表明这是一个不适定问题 [例如 Vapnik, 1998]：对于样本 $(x_1, y_1), \ldots, (x_n, y_n)$ 中未出现的任何 x 值，条件期望都没有定义. 不过，我们可以在观测样本上定义函数 f，再按照任意固定规则将其延拓（例如在样本之外令 f 为 $+1$，或选择一个连续的分段线性函数 f）. 但是，无论作出何种选择，输入即经验分布的微小变化都可能导致输出的大幅变化. 不论观测数据有多少，经验分布通常都不能完美逼近真实分布，而这种近似的微小误差可能导致估计中的巨大误差. 这意味着，若不对选择经验估计 f^n 所用的函数类作额外假设，我们无法保证估计在适当意义下逼近最优量 f.

在统计学习理论中，这些假设用容量度量来形式化. 如果所用函数类足够丰富，能够拟合大多数可以想象的数据集，那么它能够拟合手头数据也就不足为奇. 但是，如果事先限制函数类具有较小的容量，那么能够用该类中的函数解释的数据集在所有可能的数据集中只占少数. 如果这时仍能解释手头数据，我们便有理由相信自己发现了数据背后的某种规律. 在这种情况下，我们可以对解在未来从相同分布 $P_{X,Y}$ 采样的数据上的准确性给出概率保证.

另一种理解是，函数类已经纳入了与观测数据背后规律相容的先验知识（例如函数的光滑性）. 纳入这些知识的方式多种多样，不同的机器学习方法对这个问题的处理也不同. 在贝叶斯方法中，我们为函数类和噪声模型指定先验分布. 在正则化理论中，我们构造适当的正则项并将其纳入优化问题，使解偏向某些方向.

统计学习的复杂性主要源于我们试图根据经验数据求解一个逆问题——如果给定完整的概率模型，这些问题便不复存在. 讨论因果模型时我们将看到，在某种意义上，因果学习问题更难，因为它在两个层面上不适定. 除了统计上的不适定性——其根本原因是任意大小的有限样本都不可能包含底层分布的全部信息——之外，还有另一种不适定性：即使完全知道观测分布，通常也不能确定底层因果模型.

让我们更详细地考察统计学习问题，重点讨论二元模式识别或分类 [例如 Vapnik, 1998]，其中 $\mathcal{Y} = \{\pm 1\}$. 我们试图根据从未知分布 $P_{X,Y}$ 独立同分布地产生的观测 (1.1) 学习 $f : \mathcal{X} \to \mathcal{Y}$. 我们的目标是在某个函数类 $\mathcal{F}$ 上最小化期望误差或风险[2]

$$R[f] = \int \frac{1}{2} |f(x) - y| \, \mathrm{d}P_{X,Y}(x, y). \tag{1.2}$$

注意这是关于测度 $P_{X,Y}$ 的积分；不过，如果 $P_{X,Y}$ 关于 Lebesgue 测度具有密度 $p(x, y)$，则该积分化为 $\frac{1}{2} \int |f(x) - y| p(x, y) \, \mathrm{d}x \, \mathrm{d}y$.

[2]这一风险概念取自统计学习理论 [Vapnik, 1998]，并不总是与日常用法一致；它起源于统计决策理论 [Wald, 1950; Ferguson, 1967; Berger, 1985]. 在该语境下，$f(x)$ 被视为观测到 x 后采取的行动，而损失函数衡量自然状态为 y 时所遭受的损失.

由于 $P_{X,Y}$ 未知，我们无法计算式 (1.2)，更不用说将它最小化. 因此我们诉诸某种归纳原则，例如经验风险最小化：在 $f \in \mathcal{F}$ 中返回使训练误差或经验风险

$$R^n_{\text{emp}}[f] = \frac{1}{n}\sum_{i=1}^{n}\frac{1}{2}|f(x_i) - y_i| \tag{1.3}$$

最小的函数. 从渐近观点看，一个重要问题是此过程是否相合；这基本上意味着，当 n 趋于无穷时，它产生的函数序列的风险依概率收敛到给定函数类 $\mathcal{F}$ 内可能达到的最小值. 在附录 A.3 中，我们说明只有当函数类“较小”时才可能如此. Vapnik–Chervonenkis (VC) 维 [Vapnik, 1998] 是度量函数类容量或大小的一种方式. 它也使我们能够推导有限样本保证：以高概率，风险 (1.2) 不大于经验风险加上一项，而该项随函数类 $\mathcal{F}$ 的大小增长.

这样的理论并不与已有的普适相合性结果矛盾；后者指学习算法收敛到使用任意函数所能达到的最低风险. 存在普适相合的学习算法，例如最近邻分类器和支持向量机 [Devroye 等, 1996; Vapnik, 1998; Schölkopf 和 Smola, 2002; Steinwart 和 Christmann, 2008]. 普适相合性基本上告诉我们，在无限数据的极限下一切都可以学到；但由于收敛速度可能很慢，它并不意味着每个问题都可以从有限数据中学好. 对于任何学习算法，都存在学习速率任意慢的问题 [Devroye 等, 1996]. 不过，它确实告诉我们：如果固定分布并收集足够多的数据，最终就可以任意接近最低风险.

在实践中，机器学习系统近期的成功似乎表明，我们有时确实已经处于这一渐近区域，而且常常取得令人瞩目的结果. 人们投入大量思考，设计数据效率最高的方法，以从给定数据集中获得尽可能好的结果；也投入大量精力构建能够用于训练这些方法的大型数据集. 然而，在所有这些情形中，底层分布在训练和测试之间不因干预或其他变化而发生差异，都是至关重要的. 本书将论证，仅用概率分布描述底层规律而不引入额外结构，并不能为描述可能发生的变化提供合适的手段.

1.3 因果建模与学习

因果建模从另一种可以说更为基础的结构出发. 因果结构蕴含概率模型，但它包含后者所不含的额外信息（见第 1.4 节的例子）. 按本书所用术语，因果推理指从因果模型得出结论的过程，类似于概率论使我们能够推理随机试验的结果. 然而，由于因果模型比概率模型包含更多信息，因果推理比概率推理更强，因为它使我们能够分析干预或分布变化的影响.

正如统计学习指概率论的逆问题，我们也可以考虑如何从经验后果推断因果结构. 经验后果可以纯粹来自观测，也可以包括干预（如随机试验）或分布变化下的数据. 研究者使用多种术语指称这些问题，包括结构学习和因果发现. 与此密切相关的另一个问题是，原则上可以从联合分布推断出因果结构的哪些部分，我们称之为结构可识别性. 与第 1.2 节所述的标准统计学习问题不同，即使完全知道 P，求解也并非易事，我们还需要额外假设（见第 2、4、7 章）. 不过，这一困难不应使我们忽略通常的统计问题的不适定性仍然存在（因而在因果领域中，关注函数类的容量也很重要，例如通过使用加性噪声模型——见第 4.1.4 节）；它只是与另一种困难交织在一起：我们试图估计的结构比概率结构更丰富. 我们将这一整体问题称为因果学习. 图 1.1 总结了上述问题和模型

之间的关系.

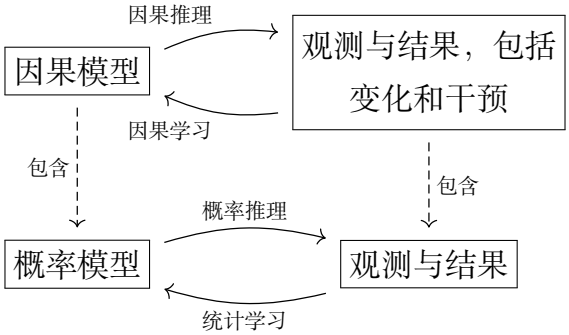


图 1.1: 本书对各种概率推断问题（下方）与因果推断问题（上方）所使用的术语，见第 1.3 节. 我们使用 “推断” 一词同时涵盖学习与推理.

要从观测分布学习因果结构，我们需要理解因果模型与统计模型之间的关系. 我们将在第 4 章和第 7 章回到这一问题，现在先给出一个例子. 一个众所周知的说法是，相关不意味着因果；换言之，仅凭统计性质无法确定因果结构. 较少有人知道，我们可以设定：虽然无法推断具体的因果结构，但至少可以从统计依赖关系推断因果联系的存在. Reichenbach [1956] 首先认识到这一点；现在我们表述他的见解（另见图 1.2）.[3]

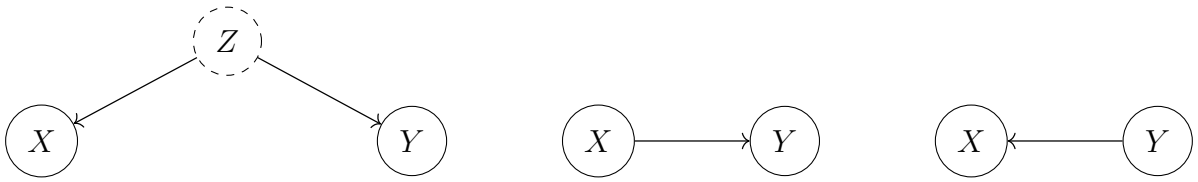


图 1.2: Reichenbach 的共同原因原则建立了统计性质与因果结构之间的联系. 两个可观测量 X 与 Y 之间的统计依赖表明它们由变量 Z 导致，Z 通常称为混杂变量（左）. 此处 Z 可以与 X 或 Y 之一重合，此时图简化为中图或右图. 该原则还指出，给定 Z 时，X 和 Y 在统计上独立. 图中箭头表示直接因果作用，见第 3 章和第 6 章.

原则 1.1（Reichenbach 的共同原因原则） 如果两个随机变量 X 和 Y 在统计上不独立（$X \not\perp\!\!\!\perp Y$），那么存在第三个变量 Z，它对二者都有因果影响.（作为特例，Z 可以与 X 或 Y 之一重合.）此外，该变量 Z 将 X 和 Y 彼此屏蔽，即给定 Z 时二者独立：$X \perp\!\!\!\perp Y \mid Z$.

在实践中，依赖关系也可能由共同原因原则中所述之外的原因产生，例如：

1. 我们观测的随机变量以其他变量为条件（通常通过选择偏差隐含地发生）. 我们将回到这一问题，见注 6.29.

2. 随机变量仅仅看似依赖. 例如，它们可能是对大量随机变量对进行搜索所得的结果，而该搜索未作多重检验校正. 此时，推断变量之间存在依赖关系并不满足所期望的第一类错误控制，见附录 A.2.

[3]为清楚起见，我们将某些重要假设表述为原则. 本书并不始终将其视为理所当然；在这个意义上，它们不是公理.

3. 类似地，两个随机变量都可能继承时间依赖性并遵循简单的物理规律，例如指数增长. 这些变量看起来似乎互相依赖，但由于独立同分布假设被违背，没有理由应用标准独立性检验. 尤其在报告随机变量之间的 “虚假相关” 时——许多大众网站正是这样做的——应当牢记第 2、3 点.

1.4 两个例子

1.4.1 模式识别

作为第一个例子，我们考察光学字符识别，这是机器学习中一个得到充分研究的问题. 这不是一个常见的因果结构例子，但对熟悉机器学习的读者或许有所启发. 我们描述两个因果模型，它们都使两个随机变量之间产生依赖；这两个变量分别是手写数字 X 和类别标签 Y. 两个模型具有不同的底层因果结构，却导出相同的统计结构.

模型 (i) 假设，我们向一位书写者提供一系列类别标签 y，并要求其始终写出对应的手写数字图像 x，以此生成每一对观测值. 我们假设书写者努力做好，但感知类别标签和执行绘制图像的运动程序时可能有噪声. 可以通过将图像 X 写成类别标签 Y（建模为随机变量）和某个独立噪声 N_X 的函数（或机制）f，来对这一过程建模（见图 1.3 左图）. 随后可以由 P_Y、P_{N_X} 和 f 计算 $P_{X,Y}$. 这称为观测分布；“观测” 一词指我们被动观察系统而不进行干预. X 和 Y 是相依随机变量，我们可以从观测中学习从 x 到 y 的映射，并根据图像 x 预测正确标签 y，其效果优于随机猜测.

这一因果结构中有两种可能的干预（intervention），分别导出干预分布.[4] 如果干预生成的图像 X（对它进行操作，或在图像生成后将其换成另一幅图像），那么这不会影响提供给书写者并记录在数据集中的类别标签. 形式上，改变 X 不影响 Y，因为 $Y := N_Y$. 另一方面，干预 Y 相当于改变提供给书写者的类别标签，这显然会对生成的图像产生强烈影响. 形式上，改变 Y 会影响 X，因为 $X := f(Y, N_X)$. 图中的箭头体现了这一方向性，我们认为箭头表示直接因果作用.

在另一种模型 (ii) 中，假设我们不向书写者提供类别标签，而是让书写者自己决定写哪些数字，并同时记录类别标签. 此时，图像 X 与记录的类别标签 Y 都是书写者意图的函数（将意图记为 Z 并视作随机变量）. 为保持一般性，我们假设生成图像和记录类别标签的过程都有噪声，噪声项仍然相互独立（见图 1.3 右图）. 注意，只要恰当地选择函数和噪声项，就可以使这一模型蕴含的观测分布 $P_{X,Y}$ 与模型 (i) 蕴含的观测分布完全相同.[5]

现在讨论模型 (ii) 中可能的干预. 如果干预图像 X，情形与刚才讨论的相同：类别标签 Y 不受影响. 但如果干预类别标签 Y（即改变书写者记录的类别标签），那么与前一种模型不同，这不会影响图像.

总之，如果不限制所涉及的函数类与分布，模型 (i) 和 (ii) 所描述的因果模型在 X, Y 上诱导相同的观测分布，却诱导不同的干预分布. 这种差别在纯概率描述中不可见（在那里一切都由 $P_{X,Y}$ 导出）. 但通过纳入关于 $P_{X,Y}$ 如何产生的结构知识，特别是图结构、函数和噪声项，我们得以讨论这一差别.

[4] 我们将在第 6.3 节看到，更一般地说，干预会改变函数和随机变量.

[5] 事实上，命题 4.1 蕴含任何联合分布 $P_{X,Y}$ 都可以由这两个模型蕴含.

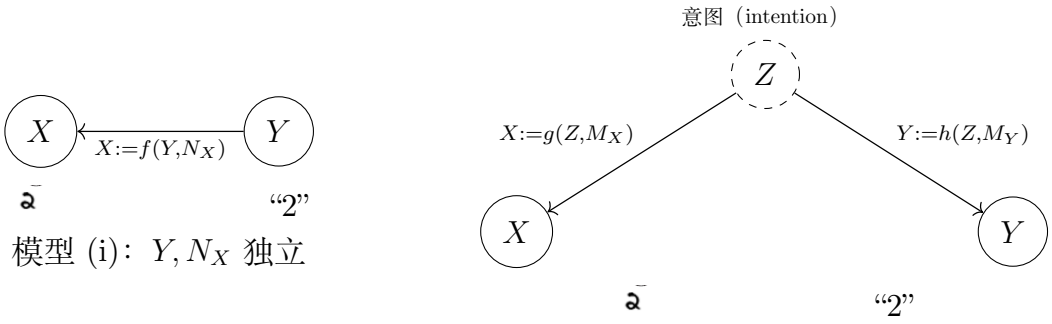


图 1.3: 手写数字数据集的两个结构因果模型. 左侧模型 (i) 向书写者提供类别标签 Y，由其生成图像 X；右侧模型 (ii) 中书写者决定写哪个类别（Z），并同时生成图像和类别标签. 对适当的函数 f, g, h 和噪声变量 N_X, M_X, M_Y, Z，两个模型产生相同的可观测分布 $P_{X,Y}$，但干预行为不同；见第 1.4.1 节.

模型 (i) 和 (ii) 是结构因果模型（structural causal model，SCM）的例子，有时也称为结构方程模型［例如 Aldrich, 1989；Hoover, 2008；Pearl, 2009；Pearl 等, 2016］. 在 SCM 中，所有依赖关系都由根据其他变量计算某个变量的函数生成. 关键在于，这些函数应当理解为赋值，也就是计算机科学意义上的函数，而不是数学方程. 我们通常认为它们对物理机制建模. SCM 蕴含所有可观测量的联合分布. 我们已经看到，同一个分布可以由不同的 SCM 生成，因此当我们从 SCM 转到相应的概率模型时，关于干预效果的信息（以及第 6.4 节将讨论的反事实信息）可能丢失. 本书以 SCM 为出发点，试图从中发展全部内容.

最后说明与例子有关的两点. 第一，图 1.3 很好地说明了 Reichenbach 的共同原因原则. X 和 Y 之间的依赖可以有多种因果解释；在右图中，以 Z 为条件时 X 和 Y 独立：图像和标签没有共享意图之外的信息.

第二，人们有时说，只有考虑时间的概念才能讨论因果性. 的确，时间在上述例子中发挥了作用，例如它排除了对 X 的干预会影响类别标签的可能性. 然而这完全没有问题，而且统计数据集通常确由随时间发生的过程生成. 例如，在模型 (i) 中，X 和 Y 之间统计依赖的底层原因是一个动力学过程：书写者读取标签并计划动作，这涉及大脑中复杂的过程，最后使用肌肉和笔执行动作. 我们对这一过程的理解只是部分的，但它是一个在时间中发生的物理动力学过程，其最终结果导致 X 和 Y 具有非平凡的联合分布. 进行统计学习时，我们只关心最终结果. 因此，不只是因果结构，纯概率结构也可能由随时间发生的过程产生——甚至可以认为这归根到底是它们产生的唯一方式. 但在这两种情况下，忽略时间往往都很有启发性. 在统计学中，讨论统计依赖等概念通常不需要时间；在因果模型中，讨论干预效果通常也不需要时间. 不过，这两个层次的描述都可以看作对底层更精确物理模型的抽象，后者比二者中任何一个都更全面地描述现实，见表 1.1. 此外，模型中的变量未必指向定义明确的时刻. 例如，心理学家研究学生动机与表现之间的统计或因果关系时，很难将这两个变量对应到特定时刻. 指向定义明确时刻的测量，更常见于物理学和化学等“硬”科学.

模型	独立同分布下预测	分布变化或干预下预测	反事实问题	物理洞见	从数据学习
机制/物理模型，如第 2.3 节	是	是	是	是	?
结构因果模型，如第 6.2 节	是	是	是	?	?
因果图模型，如第 6.5.2 节	是	是	否	?	?
统计模型，如第 1.2 节	是	否	否	否	是

表 1.1: 模型的一种简单分类. 最详细的模型（上）是机制或物理模型，通常涉及微分方程组. 在另一端（下）是纯统计模型；它可以从数据中学习，但除了为表面现象之间的关联建模之外，往往不能提供多少洞见. 因果模型可以看作介于两者之间的描述：它们抽去物理现实性，却保留回答某些干预或反事实问题的能力. 关于物理模型与结构因果模型的联系，见 Mooij 等 [2013]；关于干预，见第 6.3 节.

1.4.2 基因扰动

我们在第 1.4.1 节看到，不同的因果结构会导致不同的干预分布. 有时，我们确实想预测某个随机变量在这种干预下的结果. 考虑下面这个来自遗传学的例子；它在某些方面过于简化. 假设给定基因 A 的活性数据以及相应的表型测量值；一个玩具数据集见图 1.4 左上图. 显然两个变量高度相关. 可以利用这种相关性进行经典预测：如果观测到基因 A 的活性在 6 附近，我们预期表型以高概率位于 12 到 16 之间. 基因 B 的情形类似（左下图）. 另一方面，我们也可能想预测删除基因 A 之后的表型，即将其活性设为 0 之后的表型.[6] 然而，如果对因果结构一无所知，就不可能给出非平凡的回答. 如果基因 A 对表型有因果影响，我们预期干预后会出现显著变化（见右上图）. 实际上，我们或许仍能使用从观测数据中学得的同一个线性模型. 相反，如果存在一个共同原因——可能是第三个基因 C——同时影响基因 B 的活性和表型，那么对基因 B 的干预将不会影响表型（见右下图）.

与模式识别的例子一样，这里的模型也经过选择，使得基因 A 与表型的联合分布等于基因 B 与表型的联合分布. 因此，仅凭观测数据无法区分上、下两种情形，即使样本量趋于无穷也是如此. 总之，如果不愿使用因果概念，对于删除基因后预测表型的问题，我们只能回答 “不知道”.

[6]为简单起见，假设我们能够获得基因的真实活性，而没有测量噪声.

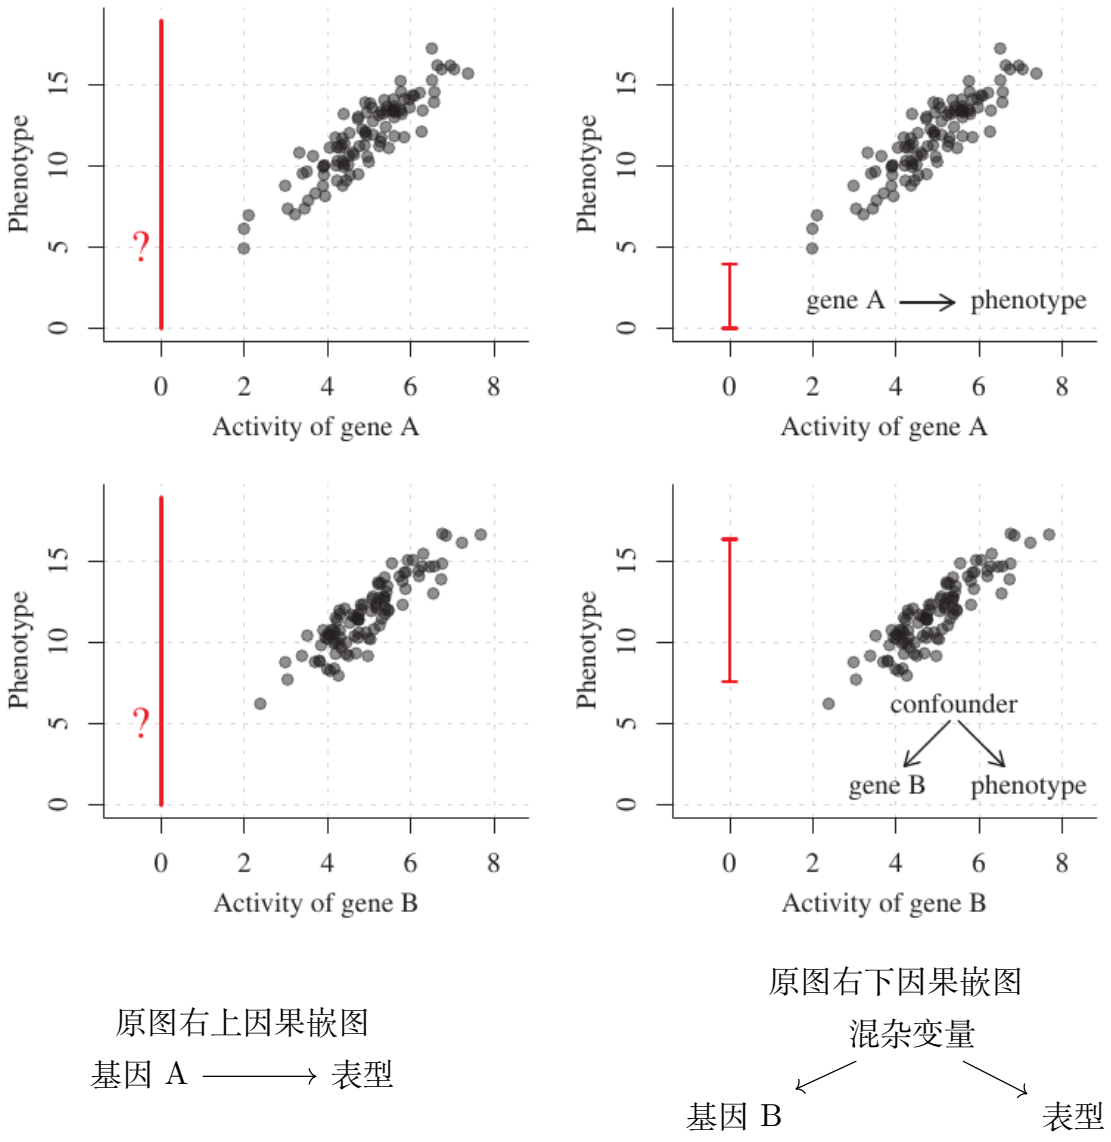


图 1.4: 两个基因（上：基因 A；下：基因 B）的活性与表型高度相关（黑点）. 但删除基因，即将其活性设为 0 时对表型的最佳预测（左），取决于因果结构（右）. 如果共同原因导致基因与表型之间的相关，我们预期干预下表型仍表现如常（右下）；如果基因对表型有因果影响，干预则会明显改变表型值（右上）. 图的构想基于 Peters 等 [2016]. 图中英文：phenotype 为表型，activity of gene 为基因活性，confounder 为混杂变量.

Chapter 2

因果推断的假设

我们已经接触了结构因果模型的基本组成部分，现在正好停下来思考我们见过的一些假设，以及这些假设对于因果推理和学习意味着什么.

在我们的讨论中，一种形式的独立性将是关键概念. 我们可以用一种被称为 Beuchet 椅的视觉错觉非正式地介绍它. 当看到图 2.1 左图那样的物体时，大脑会假设该物体与其光线所含信息传入大脑的机制相互独立. 从一个非常特殊的视点观察物体时，我们可以打破这一假设. 这时知觉会出错：我们感知到一把椅子的三维结构，而它实际上并不存在. 不过，大多数时候独立性假设确实成立. 观察物体时，大脑假定物体独立于观察视点和光照. 因此不应出现不太可能的巧合，例如分离的三维结构在二维中排成一线，或阴影边界与纹理边界重合. 视觉研究中将此称为一般视点假设［Freeman, 1994］.

不过，独立性假设比这更一般. 我们将在下面的第 2.1 节看到，因果生成过程由彼此不提供信息、也不相互影响的自主模块组成. 如下文所述，这意味着尽管一个模块的输出可能影响另一个模块的输入，模块本身仍相互独立.

在前面的例子中，尽管整体知觉是物体、光照和视点的函数，我们移动时物体和光照却不受影响——换言之，整个因果生成模型的一些组成部分保持不变，我们可以从这种不变性推断三维信息. 这是运动恢复结构［Ullman, 1979］的基本思想，它在生物视觉和计算机视觉中都起着核心作用.

2.1 独立机制原则

现在我们描述一个简单的因果问题，并指出若干观察. 随后，我们试图从统一视角说明这些观察之间的关系，论证它们都源于一个共同的独立性原则.

假设我们已经估计出某国城市样本的海拔 A 与年平均气温 T 的联合密度 $p(a,t)$（见原书第 65 页图 4.6）. 考虑以下表达 $p(a,t)$ 的方式：

$$\begin{aligned} p(a,t) &= p(a \mid t)\, p(t) \\ &= p(t \mid a)\, p(a). \end{aligned} \tag{2.1}$$

第一个分解描述了 T 和条件变量 $A \mid T$，对应按图 $T \to A$ 对 $p(a,t)$ 作因子分解.[1] 第二个分解对应按 $A \to T$ 分解（参见定义 6.21）. 我们能否判定哪一个结构是因果结构，即在哪种情况下可以将箭头理解为因果的?

第一个想法（见图 2.2 左侧）是考察干预的效果. 设想我们能够通过某种假想机制抬升城市所在的地面，从而改变城市的海拔 A. 假定我们发现平均温度下降了. 接着设想另一项干预试验：这次我们不改变海拔，而是在城市周围建设一个大型供暖系统，使

[1] 注意，给定 $p(t)$，条件密度 $p(a \mid t)$ 使我们能够计算 $p(a,t)$（因而也能计算 $p(a)$）；这暂时可以说明 $T \to A$ 中箭头的方向. 定义 6.21 将对此作精确说明.

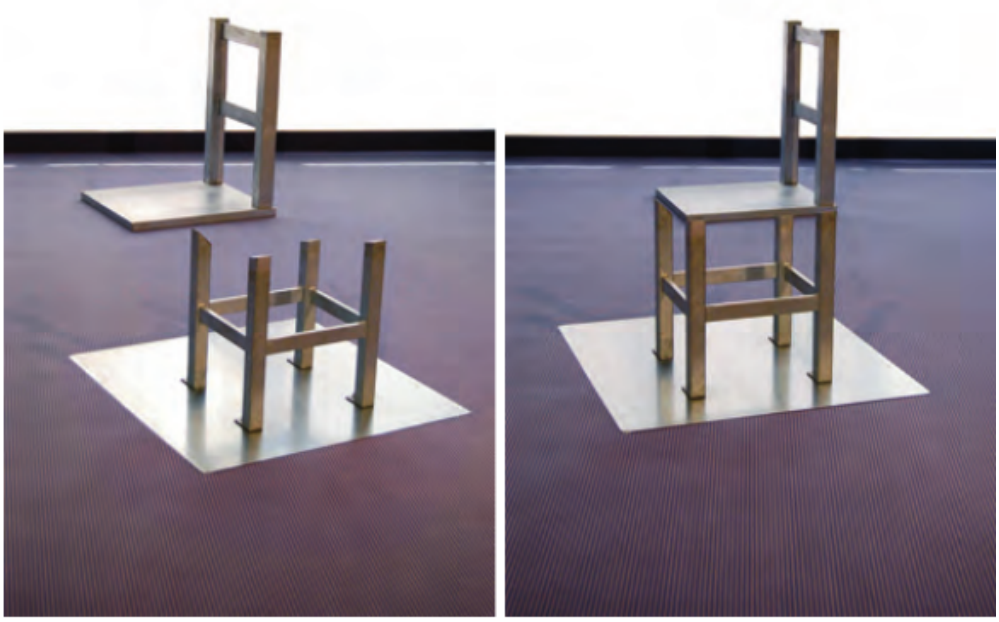


图 2.1: 左图显示构成 Beuchet 椅的（分离）部件在一般视点下的样子. 右图显示从一个极特殊的单一视点观察这些部件时所产生的椅子错觉. 从这一偶然视点，我们感知到一把椅子.（图片由 Markus Elsholz 提供.）

平均温度上升几度. 假定我们发现城市海拔没有受到影响. 对 A 的干预改变了 T，但对 T 的干预没有改变 A. 因此，合理的做法是优先选择 $A \to T$ 描述因果结构.

尽管这种假想干预在实践中很难甚至不可能实施，为什么我们认为对其效果的上述描述是可信的? 如果改变海拔 A，我们假设负责产生平均温度的物理机制 $p(t \mid a)$（例如大气的化学组成、气压随海拔下降的物理规律以及风的气象机制）仍然存在，并导致 T 变化. 这与抽取城市所用的分布无关，因而也与 $p(a)$ 无关. 奥地利人可能在与瑞士人略有不同的位置建城，但机制 $p(t \mid a)$ 在两种情况下都适用.[2]

另一方面，如果改变 T，我们很难将 $p(a \mid t)$ 想成仍然存在的机制——我们大概根本不相信存在这样的机制. 给定一组不同的城市分布 $p(a, t)$，虽然可以将它们都写为 $p(a \mid t)p(t)$，但我们会发现不可能用一个不变的 $p(a \mid t)$ 来解释所有这些分布.

可以用两种方式重新表述并假设我们的直觉：如果 $A \to T$ 是正确的因果结构，那么

(i) 原则上可以对 A 进行局部干预，换言之，可以改变 $p(a)$ 而不改变 $p(t \mid a)$;

(ii) $p(a)$ 和 $p(t \mid a)$ 是世界中自主、模块化或不变的机制或对象.

有趣的是，虽然我们从假想的干预试验出发得到因果结构，最终的推理却暗示实际干预可能并非获得因果结构的唯一途径. 我们或许还可以对数据源 $p(a, t)$ 检查式 (2.1) 的两个分解中哪一个产生自主或不变的项，以此识别因果结构. 沿用上例，将奥地利和瑞士的海拔与温度联合分布分别记为 $p_{\text{ö}}(a, t)$ 和 $p_s(a, t)$. 它们可能不同，因为奥地利人和瑞

[2]这是理想化情形——毫无疑问，可以构造这些一般性论述的反例.

士人在不同地点建城（即 $p_{\ddot{o}}(a)$ 与 $p_s(a)$ 不同）. 不过，因果分解仍可能使用相同的条件分布，即 $p_{\ddot{o}}(a,t) = p(t \mid a)p_{\ddot{o}}(a)$ 和 $p_s(a,t) = p(t \mid a)p_s(a)$.

接下来讨论一个与前例密切相关但也适用于单个分布的想法（见图 2.2 中间）. 在因果分解 $p(a,t) = p(t \mid a)p(a)$ 中，我们预期条件密度 $p(t \mid a)$（视为 t 和 a 的函数）不提供关于边缘密度函数 $p(a)$ 的信息. 如果 $p(t \mid a)$ 模拟一个不关心所输入分布 $p(a)$ 的物理机制，情况便是如此. 换言之，该机制不受它所作用的城市集合影响.

反过来，如果写成 $p(a,t) = p(a \mid t)p(t)$，上述原因与机制的独立性便不适用. 我们会发现，为了联系观测到的 $p(t)$ 和 $p(a,t)$，机制 $p(a \mid t)$ 必须具有一种由等式 $p(a,t) = p(a \mid t)p(t)$ 约束的相当特殊的形状. 给定一个城市及其温度的集合，可以对这一点作经验检验.[3]

我们已经看到几个与独立性、自主性和不变性有关的想法，它们都能为因果推断提供信息. 现在转向最后一个想法（见图 2.2 右侧），它与噪声项的独立性有关，因此最好将式 (2.1) 改写成图为 $A \to T$ 的 SCM 所蕴含的分布来解释，将结果 T 实现为原因 A 的含噪函数：

$$\begin{aligned} A &:= N_A, \\ T &:= f_T(A, N_T), \end{aligned}$$

其中 N_T 和 N_A 是统计独立的噪声：$N_T \perp\!\!\!\perp N_A$. 对 f_T 的函数形式施加适当限制（见第 4.1.3–4.1.6 节和第 7.1.2 节），使我们能够识别两个因果结构 $A \to T$ 或 $T \to A$ 中哪一个蕴含观测到的 $p(a,t)$；但没有这样的限制时，式 (2.1) 的两个分解始终都可以实现. 此外，在多元情形和适当条件下，联合独立噪声假设使我们能够通过条件独立性检验识别因果结构（见第 7.1.1 节）.

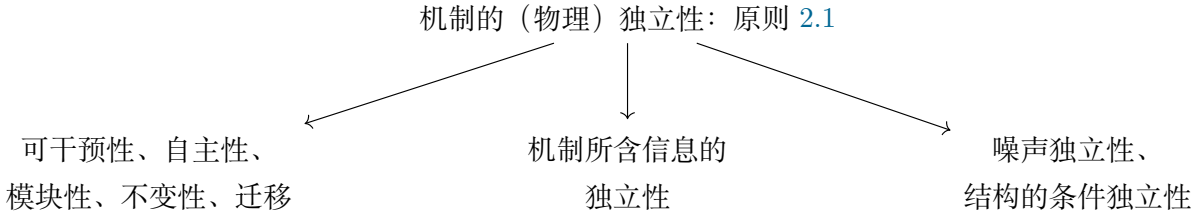


图 2.2: 独立机制原则及其对因果推断的意义（原则 2.1）.

我们倾向于将上述所有观察视为一个一般性的（物理上）独立因果机制（independent causal mechanisms，ICM）原则的密切相关的具体体现.

原则 2.1（独立机制） 系统变量的因果生成过程由彼此不提供信息、也不相互影响的自主模块组成.

在概率情形下，这意味着每个变量在给定其原因时的条件分布（即它的机制）不会对其他条件分布提供信息或施加影响. 若只有两个变量，这归结为原因分布与产生结果分布的机制之间的独立性.

如果将系统视为由包含若干变量的模块构成，而这些模块代表世界上物理独立的机制，那么该原则是可信的. 两个变量的特例被称为原因与机制独立性（ICM）[Daniušis

[3]我们将在第 4.1.7 节将这一想法形式化.

等, 2010; Shajarisales 等, 2015]. 这种看法将输入视为一个准备过程的结果，该准备过程由一个独立于将输入转化为输出之机制的机制完成.

在深入讨论这个原则之前，我们应当指出，并非所有系统都满足它. 例如，如果构成整个系统的机制通过设计或演化而彼此调适，这种独立性可能被违背.

接下来我们将论证，这一原则足够宽泛，能够涵盖因果推理与因果学习的主要方面（见图 2.2）. 下面讨论三个方面，分别对应图中从左到右的三个分支.

1. 可以将这些模块理解为体现输入—输出行为的物理机器. 这一假设意味着，我们可以改变一个机制而不影响其他机制；用因果术语来说，我们可以干预一个机制而不影响其他机制. 改变一个机制会改变其输入—输出行为，因而也会改变下游其他机制可能收到的输入，但我们假设物理机制本身不受这一变化影响. 类似假设往往被隐含地用来论证干预首先是可能的，也可以把它看作因果推理和因果学习的更一般基础. 如果一个系统允许这种局部干预，那么就不存在通过 “元机制” 以有向方式连接这些机制的物理路径. 后一点使我们有理由预期，机制相对于所考虑系统内的变化，以及可能相对于某些来自系统外的变化，也有保持不变的倾向（见第 7.1.6 节）. 当某个相关领域中的部分模块与源领域相同时，可以预期这种机制自主性有助于将一个领域学到的知识迁移到另一个领域（见第 5.2 节和第 8.3 节）.

2. 第一个方面着重讨论了独立性的物理方面及其后果；上述论述还蕴含一个信息论方面. 涉及多个相互耦合对象和机制的时间演化可以产生统计依赖. 这与我们在原书第 10 页对类别标签和手写数字图像之间依赖关系的讨论有关. 类似地，物理耦合的机制往往会产生信息，可以用统计或算法信息度量来量化（见下文第 4.1.9 节和第 6.10 节）.

   这里必须区分两个信息层次：显然，结果包含关于其原因的信息；但按照独立性原则，从原因生成结果的机制不包含关于生成原因的机制的信息. 对于具有两个以上节点的因果结构，独立性原则指出，由每个节点的直接原因生成该节点的各机制彼此不含信息.[4]

3. 最后，我们应讨论结构方程建模中通常采用的独立噪声项假设如何与独立机制原则相联系. 这一联系不那么明显. 为此，考虑变量 $E := f(C, N)$，其中噪声 N 是离散的. 对于 N 取的每个值 s，赋值 $E := f(C, N)$ 简化为一个将输入 C 转化为输出 E 的确定性机制 $E := f^s(C)$. 实际上，这意味着噪声在若干机制 f^s 之间随机选择（机制的个数等于噪声变量 N 的值域的基数）. 现在假设顶点 X_j 和 X_k 处两个机制的噪声变量在统计上相依.[5] 例如，这种依赖可能确保：每当节点 j 的某个机制 f_j^s 处于激活状态时，我们就知道节点 k 的哪个机制 f_k^t 处于激活状态. 这将违背独立机制原则.

[4]这种独立性与第 1 点所述独立性之间有一种直观联系：只要各机制独立变化，一个机制的变化就不会提供有关其他机制如何变化的信息. 尽管二者有重叠，第二种独立性仍包含第一种未严格涵盖的一个方面，因为它也适用于所有机制均未变化的情形；例如它也涉及同质数据集.

[5]尽管至此我们主要关注两个变量的情形，这里的论证也适用于具有两个以上变量的因果结构.

上一段把噪声变量看作机制之间的选择器，这种观点多少有些极端（另见第 3.4 节）. 在实践中，噪声的作用可能不那么显著. 例如，如果噪声是加性的（即 $E := f(C) + N$），它对机制的影响便受到限制. 此时它只能使机制的输出向上或向下平移，因此它是在一组彼此非常相似的机制之间选择. 这与将噪声变量视为我们试图描述的系统之外的变量相一致：它们体现了系统永远无法与环境完全隔离这一事实. 按照这种看法，噪声之间可能存在弱依赖，而不至于使独立机制原则失效.

原则 2.1 的上述各个方面都可能有助于解决因果学习问题；换言之，它们可能提供关于因果结构的信息. 但可以想见，取决于特定情形中哪些假设成立，这些信息有时也可能相互冲突.

2.2 历史注记

自主性与不变性的思想深深植根于结构方程模型（SEM）或结构因果模型（SCM）的概念中. 我们更倾向于使用后一个术语，因为在使用 SEM 一词的若干语境中，结构赋值被当作代数方程，而不是赋值. 相关文献范围广泛，Aldrich [1989]、Hoover [2008] 和 Pearl [2009] 给出了综述.

结构方程模型在思想上的一个先驱，是 Wright [1918, 1920, 1921] 开创的路径模型概念（见图 2.3）. 虽然 Wright 是生物学家，如今结构方程模型与计量经济学的联系最为紧密. 根据 Hoover [2008]，Jan Tinbergen 在 20 世纪 30 年代对结构计量经济模型作出了开创性工作，而概率计量经济学的概念基础则由 Trygve Haavelmo 的工作奠定 [Haavelmo, 1944]. 早期经济学家试图从概念上理解一个事实：与相关不同，回归具有自然方向. 用 X 回归 Y 所得的解通常不是用 Y 回归 X 所得解的逆.[6] 但数据又如何告诉我们应该沿哪个方向进行回归？这是一个观测等价性问题，与计量经济学家称为识别的问题密切相关.

一些早期工作发现，使一组方程或关系成为 “结构性的” 因素 [Frisch 和 Waugh, 1933] 与不变性、自主性之间存在联系；据 Aldrich [1989]，这确实是 Frisch 等 [1948] 开创性工作中的核心概念. 此处结构关系所追求的不仅是对观测数据分布建模，而是要捕捉连接模型变量的底层结构.

当时的 Cowles 委员会是一个重要的经济研究机构，对计量经济学领域的创建起了推动作用. 其工作将因果性与结构计量经济模型的不变性质联系起来 [Hoover, 2008]. Pearl [2009] 将结构方程在系统某些变化下保持不变的思想归功于 Marschak 在 1950 年一部 Cowles 专著中的开篇章节 [Marschak, 1950]. Cowles 的工作强调了一个关键区分，即内生变量与外生变量的区分. 内生变量是建模者试图理解的变量；外生变量则由模型外部因素决定，并作为给定量. Koopmans [1950] 考察了两条确定何者应被视为外生的原则. 学科原则将学科范围之外的变量视为外生（例如天气对于经济学而言是外生的）. （更受偏好的）因果原则将那些影响其余（内生）变量、却（几乎）不受其余变量影响的变量称为外生变量.

[6] 顺便一提，尽管早期工作大多只使用线性方程，也有人尝试将结构方程模型推广到非线性情形 [Hoover, 2008].

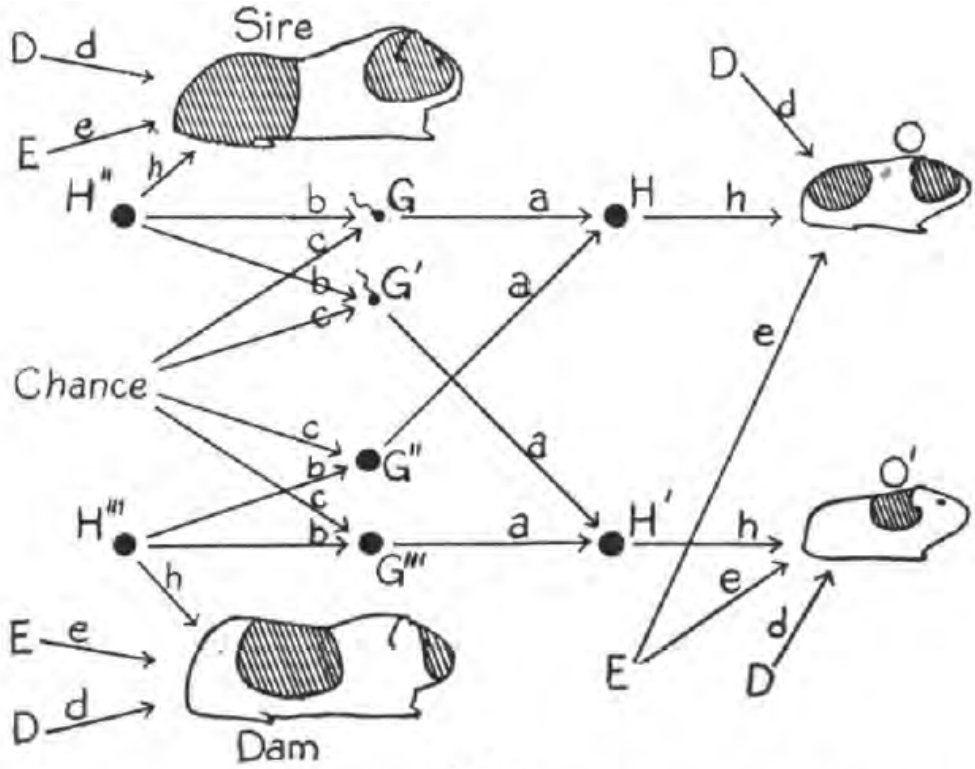


FIG. 5.

Diagram illustrating the casual relations between litter mates (O, O′) and between each of them and their parents. H, H′, H′′, H,′′′ represent the genetic constitutions of the four individuals, G, G′, G′′, and G′′′ that of four germ cells. E represents such environmental factors as are common to litter mates. D represents other factors, largely ontogenetic irregularity. The small letters stand for the various path coefficients.

图 2.3: 早期路径图；dam 和 sire 分别是豚鼠的雌性和雄性亲本. 路径系数刻画给定路径的重要性，其定义为：除所考虑原因之外的所有原因都保持不变，且该原因的变异性保持不变时所得到的结果变异性，与总变异性的比值. 转载自 Wright [1920]. 图中原有说明：H, H', H'', H''' 表示四个个体的遗传组成；G, G', G'', G''' 表示四个生殖细胞的遗传组成；E 表示同窝个体共同的环境因素；D 表示其他因素，主要是个体发育的不规则性；小写字母表示各路径系数；chance 为偶然因素.

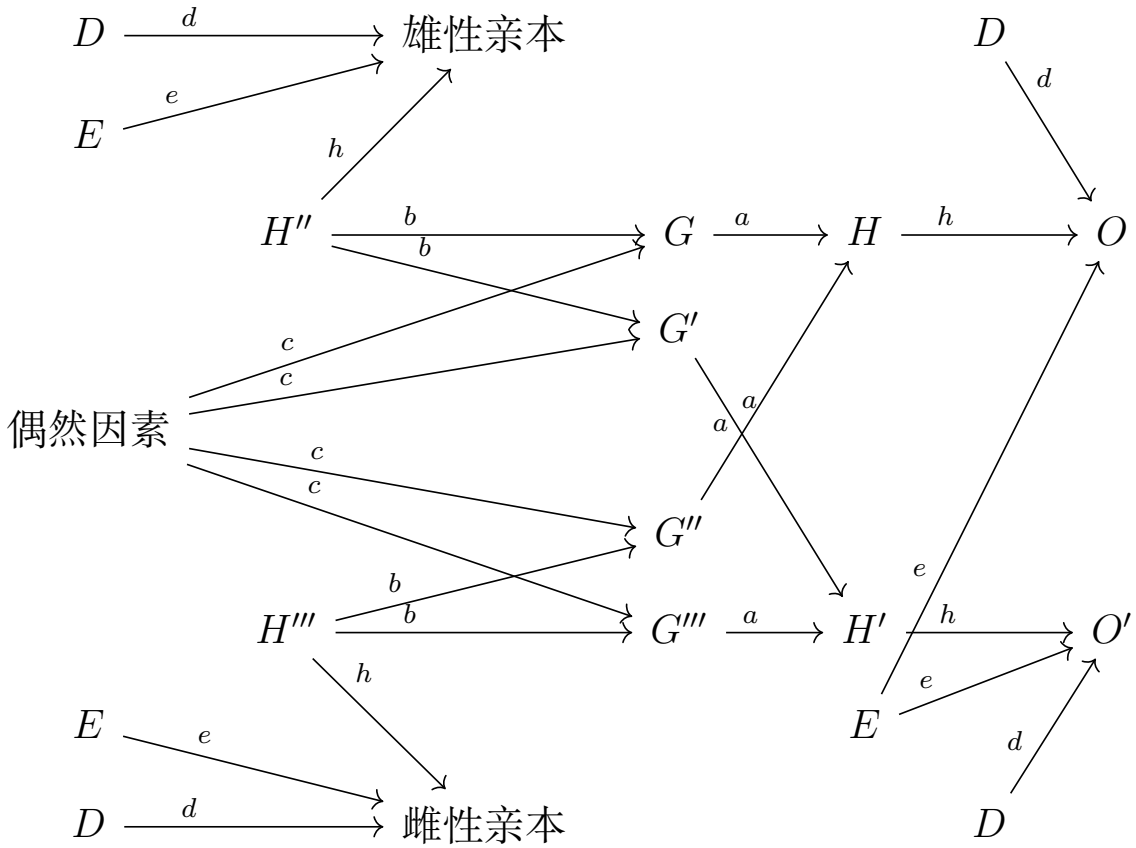


图 2.3 的可编辑路径重排. 原历史图及豚鼠图像保留于前图；本图逐边保留全部 24 条有向路径、系数及 D, E 的不同实例，亲本图像以对应文字节点表示，O, O' 为同窝后代. 连线交叉不表示额外节点.

Haavelmo [1943] 将结构方程解释为关于假想受控实验的陈述. 他考虑了有环随机方程模型，并讨论了不变性和政策干预的作用. Pearl [2015] 评述了 Haavelmo 在政策干预问题研究及因果推断领域发展中的作用. Hoover [2008] 在对经济学和计量经济学中因果性的论述里讨论了如下系统：

$$X^i := N_X^i,$$
$$Y^i := \theta X^i + N_Y^i,$$

其中误差 N_X^i, N_Y^i 独立同分布，而 θ 是参数. 他将如下观点归于 Simon [1953]：可以说 X^i 导致 Y^i，因为无需知道 Y^i 就能知道关于 X^i 的全部信息，反过来却不行；这一观点不要求任何时间顺序. 这些方程还使我们能够预测干预效果. Hoover 进一步指出，可以改写系统、颠倒 X^i 和 Y^i 的角色，同时保留误差项不相关这一性质.[7] 因此，他指出仅凭一组数据无法推断正确的因果方向（“观测等价性”）. 无论是受控实验还是自然实验，都可能帮助我们判定. 例如，如果一项实验可以改变给定 X^i 时 Y^i 的条件分布，同时不改变 X^i 的边缘分布，那么必定是 X^i 导致 Y^i. Hoover 将此称为 Simon 的不变性准则：真正的因果顺序是在适当类型的干预下保持不变的顺序.[8] Hurwicz [1962] 认为，方程组因对某个修改范围具有不变性而成为结构性的；这样的系统就类似于自然规律. Hurwicz 认识到，可以利用这样的修改确定结构，而且因果性需要结构，预测却不需要.

Aldrich [1989] 论述了自主性在结构方程建模中的作用. 他认为自主关系比其他关系更可能稳定，并将 Haavelmo 的自主变量等同于后来被称为外生变量的变量. 自主变量是由外力固定或被视为随机独立的参数.[9] 按照 Aldrich [1989, 第 30 页] 的说法，“使用限定词自主以及‘所考虑部门之外的力量’这一说法，暗示……该模型的参数对部门参数的变化是不变的.” 他还将不变性与一个称为超外生性的概念联系起来 [Engle 等, 1983].

结构方程建模的早期倡导者已经对其因果基础有过深刻见解，但计算机科学中的发展最初是独立进行的. Pearl [2009, 第 104 页] 叙述了他和合作者如何开始联系贝叶斯网络与结构方程建模：“我突然意识到，经济学家与统计学家之间长达一个世纪的紧张关系源于简单的语义混淆：统计学家将结构方程读作关于 $\mathbb{E}[Y \mid x]$ 的陈述，而经济学家将其读作 $\mathbb{E}[Y \mid do(x)]$. 这可以解释为什么统计学家声称结构方程没有意义，而经济学家反驳说统计学没有实质内容.” Pearl [2009, 第 22 页] 将独立性原则表述为：“网络中的每一个父子关系都代表一个稳定、自主的物理机制——换言之，可以设想改变其中一个关系而不改变其他关系.”

值得注意的是，这也是我们撰写本书的动机：在图 2.2 所示原则 2.1 的不同推论中，使用因果贝叶斯网络的大多数工作只利用了噪声项的独立性.[10] 它导出丰富的条件独立性结构 [Pearl, 2009; Spirtes 等, 2000; Dawid, 1979; Spohn, 1980]，最终源自 Reichenbach 的原则 1.1. 独立性的其他方面受到的关注要少得多 [Hausman 和 Woodward, 1999;

[7] 我们将在第 4.1.3 节更详细地重新讨论这一主题.

[8] 我们认为，如果干预彼此耦合，例如为保持反因果条件分布（给定结果时描述原因的条件分布）不变，这一准则可能不成立. 这可以视为在干预层面上违反原则 2.1. 我们将在第 2.3.4 节回到这一点.

[9] 这与我们在 SCM 中使用的噪声项独立性类似.

[10] 某些贝叶斯结构学习方法 [Heckerman 等, 1999] 可视为通过给定各变量的原因时对其条件概率赋予独立先验，从而实现独立性原则.

Lemeire 和 Dirkx, 2006]，但近期有一系列工作试图将其形式化并加以利用. 重要动机之一是因果问题：由于只有两个变量，条件独立性在此无用（见第 4.1.2 节和第 6.10 节）.

Janzing 和 Schölkopf [2010] 用算法信息论将机制独立性形式化（第 4.1.9 节）. 他们将 SCM 中的函数视为表示独立的因果机制；这些机制在改变输入分布或其他机制后仍然存在. 更具体地说，在因果贝叶斯网络中，他们假设所有节点给定其父节点时的条件分布在算法上相互独立. 特别地，对于因果贝叶斯网络 $X \to Y$，P_X 与 $P_{Y|X}$ 彼此不含算法信息，即知道其中一个并不能更简短地描述另一个. 无关机制在算法上独立这一思想，源于将 SCM 从随机变量推广到单个对象，在那里算法依赖取代了统计依赖.

Schölkopf 等 [2012，例如第 2.1.1 节] 讨论了（在双变量情形中）相对于原因分布变化的稳健性，并将其与机器学习问题联系起来，另见第 5 章. 在 SCM 内，他们针对不同学习情景（例如迁移学习、概念漂移）分析函数或噪声的不变性. 他们使用一个涵盖变化下独立性与信息论独立性的机制与输入独立性概念（在讨论图 2.2 各框时，我们称之为第一、第二种独立性的“重叠”）：“$P_{E|C}$ 不包含关于 P_C 的信息，反之亦然；特别地，如果 $P_{E|C}$ 在某个时刻变化，没有理由相信 P_C 会同时变化.”

Bareinboim 和 Pearl [2016]、Rojas-Carulla 等 [2016]、Zhang 等 [2013] 和 Zhang 等 [2015] 讨论了与迁移及相关机器学习问题的进一步联系. Peters 等 [2016] 利用跨环境不变性学习多元 SCM 底层图结构的一部分（第 7.1.6 节）.

2.3 因果模型背后的物理结构

本章最后讨论与物理学的若干联系. 兴趣仅限于数学和统计结构的读者或许愿意跳过这一部分.

2.3.1 时间的作用

第 2.1 节明显缺少的一个方面是时间的作用. 事实上，物理学通过排除从未来到过去的因果作用，将因果性纳入其基本定律.[11] 不过，这并不能消除因果推断的所有问题. Simon [1953] 早已认识到，虽然时间顺序能够提供有用的不对称性，但重要的是不对称性，而不是时间上的先后顺序.

人们普遍认为，在微观尺度上，经典系统和量子力学系统的时间演化都是可逆的. 这似乎与我们对世界沿某个方向演化的直觉相矛盾：我们相信自己能够识别时间是否倒流. 可以通过两种方式化解这一矛盾. 第一种方式是假设我们有一个衡量状态复杂度的量 [Bennett, 1982；Zurek, 1989]，并从复杂度很低的状态出发. 此时，时间演化（假设其遍历性足够强）将倾向于增加复杂度. 另一种方式是假设我们考虑的是开放系统. 即使封闭系统的时间演化是可逆的（例如量子力学中的幺正时间演化），开放子系统（与环境相互作用）在一般情况下的时间演化也不一定可逆.

[11] 更准确地说，一个事件只能影响其光锥中的事件，因为根据相对论，没有信号能够超过真空中的光速.

2.3.2 物理定律

可以用下面的例子讨论一个经常被问及的因果问题. 理想气体定律规定，压强 p、体积 V、物质的量 n 和绝对温度 T 满足方程

$$p \cdot V = n \cdot R \cdot T, \tag{2.2}$$

其中 R 是理想气体常数. 例如，如果改变给定量气体所占的体积 V，那么压强 p 和 / 或温度 T 会发生变化，具体情况取决于干预的确切设置. 另一方面，如果改变 T，则 V 和 / 或 p 会变化. 如果保持 p 不变，我们至少可以近似地构造一个涉及 T 和 V 的循环. 那么究竟什么导致什么？有时有人认为，这类定律表明除非系统具有时间性，否则谈论因果性没有意义. 我们接下来认为这是有误导性的. 气体定律 (2.2) 指的是底层动力系统的平衡态，把它写成一个简单方程并没有提供足够信息，说明原则上可以进行哪些干预以及干预会产生什么效果. SCM 及其对应的有向无环图确实提供这些信息，但对于一般非平衡系统，给定的动力系统是否以及如何导出 SCM 是一个困难的问题.

2.3.3 有环赋值

我们将 SCM 看作对随时间发生的底层过程的抽象. 对这些底层过程而言，反馈回路没有问题，因为在足够快的时间尺度上，这些回路会沿时间展开；这里假设不存在瞬时相互作用，而光速有限可以说排除了这种相互作用.

尽管随时间变化的过程没有环，从这类过程导出的 SCM（例如使用下文注 6.5 和 6.7 中提到的方法），即使仅涉及不再依赖时间的量，也可能有环. 在这样的系统中定义一般干预会稍微困难一些，但某些类型的干预仍应当可行. 例如，将某个变量设为固定值的硬干预可能可行（并可通过底层微分方程组中的一个强迫项在物理上实现；见注 6.7）. 这会切断环，然后我们可以推导所蕴含的干预分布.

不过，从一组有环结构赋值中推导出所蕴含的观测分布可能是不可能的. 考虑两个赋值

$$\begin{aligned} X &:= f_X(Y, N_X), \\ Y &:= f_Y(X, N_Y), \end{aligned}$$

以及噪声变量 $N_X \perp\!\!\!\perp N_Y$. 与无环模型的情形一样，我们把噪声和函数视为给定，试图计算所蕴含的 X, Y 联合分布. 为此，先从第一个赋值 $X := f_X(Y, N_X)$ 出发，代入某个初始的 Y；得到 X 后，再将它代入另一个赋值. 假设我们迭代这两个赋值并收敛到某个不动点. 这一点将对应一个 X, Y 的联合分布，使两个结构赋值同时作为随机变量之间的等式成立.[12] 注意，我们这里假设每一步使用相同的 N_X, N_Y，而不是它们的独立副本.

然而，X, Y 的这种平衡不一定总是存在；即使存在，也不一定能通过迭代找到. 在线性情形下，Lacerda 等 [2008] 和 Hyttinen 等 [2012] 对此进行了分析；另见 Lauritzen 和 Richardson [2002]. 更多细节见注 6.5.

[12] 赋值作为随机变量之间的等式成立，意味着我们考虑的是一组系统，它们的噪声变量实现值各不相同. 每个实现值都会导出 X, Y 的一个（可能不同的）实现值，因此噪声的分布蕴含 X, Y 的一个分布.

可能无法得到满足两个有环结构赋值的蕴含分布，这一观察与将 SCM 视为底层物理过程的抽象的观点相一致——这些抽象作为因果模型的有效范围有限. 如果希望理解一般有环系统，或许不可避免地需要研究微分方程组，而不是 SCM. 另一方面，在某些受限条件下，停留在现象学上较表层的 SCM 层次仍可能有意义，例如见 Mooij 等 [2013]. 可以推测，SCM（或 SEM）固有的这一困难，是计量经济学界最初将 SEM 视为因果模型、但后来该领域部分研究者放弃这种解释而将结构方程视为纯代数方程的部分原因.

2.3.4 干预的可行性

我们利用独立机制原则来说明每次只影响一个机制（或结构赋值）的干预. 尽管真实系统可能允许这类干预，也会有同时替换多个赋值的干预. 从直观的物理意义上看，前一类干预可以被认为更基本. 如果将多个基本干预组合起来，原则上它们可能以彼此调适的方式进行；我们会将此视为违背了原则 2.1 的某种独立性，见原书第 24 页脚注 8. 人们可以希望 “自然的” 组合干预不会违背独立性. 然而，判断一个干预在此意义上是否 “自然” 需要知道因果结构；当我们试图利用这类原则进行因果学习时，一开始恰恰不知道因果结构. 归根到底，我们可以尝试诉诸物理学来考察什么是基本的或自然的.

对一个物理系统而言，哪些操作是基本操作，这一问题在现代量子信息理论中起关键作用. 在那里，该问题与分析物理相互作用的结构密切相关.[13] 同样地，我们认为，理解因果关系背后的物理机制，有时可以解释为什么某些干预是自然的而其他干预是复杂的；这基本上定义了不同结构方程所给出的 “模块”.

2.3.5 原因与机制独立性及热力学时间箭头

我们通过讨论和一个玩具模型说明如何将独立机制原则视为物理学原则. 为此，考虑两个变量的特例，并将以下内容设定为原则 2.1 的一个特化：

原则 2.2（初始状态与动力学定律） 如果 s 是物理系统的初始状态，M 是描述施加系统动力学某一固定时间所产生效果的映射，那么 s 与 M 独立. 此处我们假设，按照定义，初始状态是此前未与该动力学发生相互作用的状态.

这里，“初始” 状态 s 和 “最终” 状态 $M(s)$ 分别被视作 “原因” 和 “结果”. 相应地，M 是联系原因与结果的机制. 为避免得出错误结论，原则 2.2 的最后一句需要解释. 下面通过一个直观例子讨论其含义.

图 2.4 展示了一个初始状态与动力学的独立性如此自然、以至于我们将其视为理所当然的情形：一束由 n 个沿完全相同方向传播的粒子组成的粒子束接近某个物体，并被散射到不同方向. 出射粒子的方向包含关于该物体的信息，而入射粒子束不包含关于它的信息. 当然，可以放宽粒子最初沿完全相同方向传播的假设. 即使入射束中存在一定无序，出射束仍可以包含关于物体的信息. 实际上，视觉和摄影之所以可能，正是因为

[13] 供感兴趣的读者参考：由 n 个双能级量子系统组成的系统可由 2^n 维 Hilbert 空间 $\mathbb{C}^2 \otimes \cdots \otimes \mathbb{C}^2$ 描述. 作用在这个 Hilbert 空间上的幺正算符对应物理过程. 对于多个这样的系统，研究者说明了如何实现至多作用于 n 个张量分量中的两个 [Nielsen 和 Chuang, 2000]、而在其余 $n-2$ 个分量上平凡作用的 “基本” 幺正算符. 然后通过串接可以近似生成任何其他幺正算符 [DiVincenzo, 1995]. 虽然这绝不是 “基本” 幺正操作集合的唯一可能选择，但给定物理相互作用的结构，这一选择似乎是自然的.

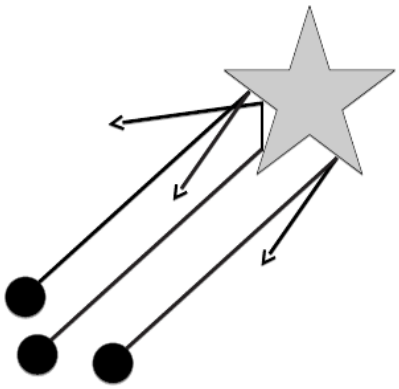


图 2.4: 初始状态与动力学定律独立性的简单例子：一束粒子被一个物体散射. 出射粒子包含关于该物体的信息，而入射粒子不包含.

光子包含关于散射它们的物体的信息.

我们可以通过 “手工设计” 入射束轻易地将该情形时间反演，使所有粒子在散射过程之后沿同一方向传播. 现在我们讨论这种情况下应如何理解原则 2.2. 显然，只有知道物体形状并据此引导粒子的机器或主体才能制备这样的粒子束. 事实上，从未与物体接触的粒子不能先验地包含关于它的信息. 因此，如果我们把引导粒子的过程看作机制的一部分，并拒绝将手工设计的粒子束的状态称为初始状态，那么原则 2.2 仍可维持. 此时，初始状态指的是粒子被赋予经过精细调节的动量之前的时刻.

照片显示过去发生的事情而不是未来将发生的事情，这一事实是过去与未来之间最明显的不对称性之一. 上述讨论表明，可以将这种不对称性视为原则 2.2 的一个推论. 因此，该原则将原因与结果之间的不对称性，与我们视为理所当然的过去与未来之间的不对称性联系起来.

在非正式层面解释原则 2.1 与物理学中过去和未来不对称性之间的关系后，我们简要指出，Janzing 等 [2016] 利用算法信息论更形式化地建立了这一联系. 正如原则 4.13 将 P_C 与 $P_{E|C}$ 的独立性形式化为算法独立性，原则 2.2 也可以解释为 s 与 M 的算法独立性. Janzing 等 [2016，定理 1] 表明，对任意双射 M，只要愿意接受 Bennett [1982] 和 Zurek [1989] 所提出的以 Kolmogorov 复杂度（见第 4.1.9 节）作为物理熵的恰当形式化，那么原则 2.2 就蕴含 $M(s)$ 的物理熵不能小于 s 的熵（相差一个加性常数）. 因而，原则 2.2 蕴含物理学标准时间箭头意义下的熵不减.

Chapter 3

因果对模型

本章针对因果模型只包含两个变量的情形，将一些基本因果概念形式化. 假设这两个变量存在非平凡联系，且它们的依赖并不完全由共同原因造成，这就构成一个因果对模型. 我们简要介绍结构因果模型、干预和反事实. 这些概念都会在多元因果模型的背景下（第 6 章）重新定义；我们希望先在双变量情形中接触这些概念，可以使它们更容易理解.

3.1 结构因果模型

结构因果模型是联系因果陈述与概率陈述的重要工具.

定义 3.1（结构因果模型） 图为 $C \to E$ 的结构因果模型 $\mathfrak{C}$ 由两个赋值组成：

$$C := N_C, \tag{3.1}$$

$$E := f_E(C, N_E), \tag{3.2}$$

其中 $N_E \perp\!\!\!\perp N_C$，即 N_E 与 N_C 独立.

在这一模型中，我们将随机变量 C 称为原因，将 E 称为结果. 此外，我们称 C 是 E 的直接原因，并将 $C \to E$ 称为因果图. 我们希望这种记号在讨论干预时能够使概念清楚并符合读者的直觉，例如见例 3.2.

如果给定函数 f_E 和噪声分布 P_{N_C}, P_{N_E}，就可以按以下方式从模型采样：先采样噪声值 N_E, N_C，再依次计算式 (3.1) 和式 (3.2). 因此，结构因果模型在 C, E 上蕴含一个联合分布 $P_{C,E}$（形式证明见命题 6.3）.

3.2 干预

如第 1.4.2 节所述，我们经常关心系统在干预下的行为. 被干预的系统诱导另一个分布，它通常不同于观测分布. 如果任意一种干预都可能引起系统任意变化，那么两个分布便失去联系；我们可以将它们视为两个独立系统，而不是联合研究. 这促使我们考虑这样的思想：干预后只有数据生成过程的一部分发生变化. 例如，我们可能关心变量 E 被设为 4（无论 C 取什么值），而生成 C 的机制 (3.1) 不变的情况. 也就是说，我们将赋值 (3.2) 替换为 $E := 4$. 这称为（硬）干预，记作 $do(E := 4)$. 替换式 (3.2) 后，修改过的 SCM 在 C 上蕴含一个分布，我们将其记为 $P_C^{do(E:=4)}$ 或 $P_C^{\mathfrak{C};do(E:=4)}$；后者明确表明 SCM $\mathfrak{C}$ 是出发点. 相应的密度记作 $c \mapsto p_C^{do(E:=4)}(c)$，或略有滥用记号地写作 $p^{do(E:=4)}(c)$.[1] 然而操作可以更加一般. 例如，干预 $do(E := g_E(C) + \widetilde{N}_E)$ 保留对 C 的函

[1] 文献中也常用记号 $p(c \mid do(E := 4))$. 我们更喜欢 $p^{do(E:=4)}$，因为干预与条件化在概念上不同，而 $p(c \mid do(E := 4))$ 与后者的通常记号 $p(c \mid E = 4)$ 相似.

数依赖，却改变噪声分布. 这是软干预的一个例子. 两个方程中的任意一个都可以被替换.

下例说明 “原因” 与 “结果” 这两个名称的动机：

例 3.2（因果对干预） 假设分布 $P_{C,E}$ 由图为 $C \to E$ 的 SCM $\mathfrak{C}$ 蕴含：

$$\begin{aligned} C &:= N_C, \\ E &:= 4 \cdot C + N_E, \end{aligned} \tag{3.3}$$

其中 $N_C, N_E \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$. 则

$$\begin{aligned} P_E^{\mathfrak{C}} = \mathcal{N}(0,17) \neq \mathcal{N}(8,1) = P_E^{\mathfrak{C};do(C:=2)} = P_{E|C=2}^{\mathfrak{C}} \\ \neq \mathcal{N}(12,1) = P_E^{\mathfrak{C};do(C:=3)} = P_{E|C=3}^{\mathfrak{C}}. \end{aligned}$$

对 C 的干预改变 E 的分布. 但另一方面，

$$P_C^{\mathfrak{C};do(E:=2)} = \mathcal{N}(0,1) = P_C^{\mathfrak{C}} = P_C^{\mathfrak{C};do(E:=314159265)} \neq P_{C|E=2}^{\mathfrak{C}}. \tag{3.4}$$

不论对 E 的干预有多强，C 的分布都保持原样. 这一模型行为与我们对 C “导致” E 的直觉很相符：例如，不管把一个人的牙齿美白到什么程度，都不会影响此人的吸烟习惯. （重要的是，给定 $E = 2$ 时 C 的条件分布不同于干预并将 E 设为 2 后 C 的分布.）

原因与结果的不对称性也可以表述为独立性陈述. 当我们将赋值 (3.3) 替换为 $E := \widetilde{N}_E$（可理解为随机化 E）时，便打破了 C 与 E 的依赖. 在 $P_{C,E}^{\mathfrak{C};do(E:=\widetilde{N}_E)}$ 下，我们有 $C \perp\!\!\!\perp E$. 随机化 C 时，这种独立性不成立. 只要 $\operatorname{var}[\widetilde{N}_C] \neq 0$，在 $P_{C,E}^{\mathfrak{C};do(C:=\widetilde{N}_C)}$ 下就有 $C \not\perp\!\!\!\perp E$；C 与 E 之间的相关仍非零.

代码片段 3.3 以下代码从例 3.2 中的 SCM 采样.

```
set.seed(1)
# 从 SCM 蕴含的分布生成样本
C <- rnorm(300)
E <- 4*C + rnorm(300)
c(mean(E), var(E))
# [1] 0.1236532 16.1386767
# 从干预分布 do(C:=2) 生成样本；这会改变 E 的分布
C <- rep(2,300)
E <- 4*C + rnorm(300)
c(mean(E), var(E))
# [1] 7.936917 1.187035
# 从干预分布 do(E:=N~) 生成样本；这打破 C 与 E 的依赖
C <- rnorm(300)
E <- rnorm(300)
cor.test(C,E)$p.value
# [1] 0.2114492
```

3.3 反事实

SCM 的另一种可能修改会改变其所有噪声分布. 这种变化可以由观测诱导，使我们能够回答反事实（counterfactual）问题. 为说明这一点，设想以下假想情景：

例 3.4（眼疾） 某种眼疾有一种相当有效的治疗方法. 对 99% 的患者，治疗有效，患者得以治愈（$B = 0$）；若不治疗，这些患者一天内会失明（$B = 1$）. 对其余 1% 的患者，治疗有相反效果，他们会在一天内失明（$B = 1$）；如果不治疗，他们会恢复正常视力（$B = 0$）.

患者属于哪一类由一种罕见状况（$N_B = 1$）控制. 医生不知道这种状况，因此其是否施治（$T = 1$）的决定独立于 N_B. 我们将该决定写成噪声变量 N_T.

假设底层 SCM 为

$$\mathfrak{C}: \quad \begin{cases} T := N_T, \\ B := T \cdot N_B + (1 - T) \cdot (1 - N_B), \end{cases} \tag{3.5}$$

其中 $N_B \sim \mathrm{Ber}(0.01)$ 服从 Bernoulli 分布；注意对应的因果图是 $T \to B$.

现在设想一位视力不佳的特定患者来到医院，医生施治（$T = 1$）后患者失明（$B = 1$）. 我们可以提出反事实问题：“如果医生采取 $T = 0$，会发生什么？”令人惊讶的是，这个问题可以回答. 由观测 $B = T = 1$ 和式 (3.5) 可知，这位患者有 $N_B = 1$. 进而我们可以计算 $do(T := 0)$ 的效果.

为此，首先以观测为条件更新噪声变量的分布. 正如我们所见，在给定 $B = T = 1$ 的条件下，N_B 和 N_T 的分布都退化为在 1 处的点质量，即 δ_1. 由此得到修改后的 SCM：

$$\mathfrak{C} \mid B = 1, T = 1: \quad \begin{cases} T := 1, \\ B := T \cdot 1 + (1 - T) \cdot (1 - 1) = T. \end{cases} \tag{3.6}$$

注意，我们只更新噪声分布；条件化不会改变赋值本身的结构. 其思想是物理机制不变（本例中是导致治愈和导致失明的机制），但我们获得了关于该患者先前未知的噪声变量的信息.

接下来计算对这位患者实施 $do(T := 0)$ 的效果：

$$\mathfrak{C} \mid B = 1, T = 1; do(T := 0): \quad \begin{cases} T := 0, \\ B := T. \end{cases} \tag{3.7}$$

显然，所蕴含的分布将全部质量放在 $(0, 0)$ 上，因而

$$P^{\mathfrak{C} \mid B=1, T=1; do(T:=0)}(B = 0) = 1.$$

这意味着，如果医生没有对患者施治，即 $do(T := 0)$，患者本会治愈（$B = 0$）. 然而，由于

$$P^{\mathfrak{C}; do(T:=1)}(B = 0) = 0.99,$$
$$P^{\mathfrak{C}; do(T:=0)}(B = 0) = 0.01,$$

我们仍然可以认为医生（根据可获得的知识）采取了最优行动.

有趣的是，例 3.4 表明我们可以利用反事实陈述证伪底层因果模型（见第 6.8 节）. 假设可以检测罕见状况 N_B，但检测结果需要一天以上才能得到. 在这种情况下，我们可能观测到一个与 N_B 的测量结果相矛盾的反事实陈述. Pearl [2009, 第 220 页，第 (2) 点] 给出了相同论证. 由于反事实的科学内容曾受到广泛争论，需要强调：这里的反事实陈述可被证伪，是因为噪声变量原则上并非不可观测，只是在医生必须作决定的时刻不可观测.

3.4 结构因果模型的规范表示

我们已经讨论了 SCM 所蕴含的两类因果陈述：第一类是系统在可能的干预下的行为，第二类是反事实陈述. 为进一步理解二者的区别，我们引入 SCM 的如下 “规范表示”.[2] 根据结构赋值

$$E = f_E(C, N_E),$$

对于噪声 N_E 的每个固定值 n_E，E 是 C 的确定性函数：

$$E = f_E(C, n_E). \tag{3.8}$$

换言之，如果 C, E 分别在 $\mathcal{C}, \mathcal{E}$ 中取值，那么噪声 N_E 在从 $\mathcal{C}$ 到 $\mathcal{E}$ 的不同函数之间切换. 因此，不失一般性，可以假设 N_E 在从 $\mathcal{C}$ 到 $\mathcal{E}$ 的函数集合中取值，该集合记为 $\mathcal{E}^{\mathcal{C}}$. 采用这一约定，我们还可以将式 (3.8) 改写为

$$E = n_E(C), \tag{3.9}$$

并将其称为联系 C 和 E 的结构方程的规范表示.

现在说明为什么具有不同规范表示的两个 SCM 可能诱导相同的干预概率，尽管它们的反事实陈述不同. 为此，我们将注意力限制在 C 取值于有限集合 $\mathcal{C} = \{1, \dots, k\}$ 的情形. 那么从 $\mathcal{C}$ 到 $\mathcal{E}$ 的函数集合由 k 重笛卡尔积给出：

$$\mathcal{E}^k := \underbrace{\mathcal{E} \times \cdots \times \mathcal{E}}_{k \text{ 次}},$$

其中第 j 个分量描述当 $C = j$ 时 E 取什么值. 相应地，分布 P_{N_E} 由 $\mathcal{E}^k$ 上的一个联合分布给出，其第 j 个分量的边缘分布决定条件分布 $P_{E|C=j}$. 因为 C 是原因、E 是结果，所以 $P_E^{do(C:=j)} = P_{E|C=j}$；换言之，此处干预概率与观测条件概率相同. 因此，SCM 的干预因果推论完全由向量值噪声变量 N_E 的各分量边缘分布决定，尽管该 SCM 精确规定了 P_{N_E}，即所有分量的联合分布. 与结果相关的噪声变量各分量之间的统计依赖，对干预性因果陈述无关紧要，但对反事实陈述却有影响.

为说明这一点，设 C, E 为二元变量，即 $\mathcal{C} = \mathcal{E} = \{0, 1\}$. 从 $\{0, 1\}$ 到 $\{0, 1\}$ 的函数集合为 $\mathcal{E}^{\mathcal{C}} = \{0, 1, \mathrm{ID}, \mathrm{NOT}\}$，其中 $0, 1$ 分别表示取常值 0 和 1 的函数，$\mathrm{ID}, \mathrm{NOT}$ 分别

[2] 这种表示已在文献中的多处使用，例如 [Pearl, 2009]，尽管我们没有发现 “规范表示” 这一名称.

表示恒等函数和取反函数. 为构造两个不同分布 $P_{N_E^1}$ 与 $P_{N_E^2}$，使它们诱导相同的条件分布 $P_{E|C=0}, P_{E|C=1}$，首先选择 0 和 1 的均匀混合，其次选择 ID 和 NOT 的均匀混合. 两种情况下 C, E 都在统计上独立，而对 C 的干预不会改变 E 的分布，因为不管 C 为何值，E 都仍是一次公平的抛硬币结果.

在笛卡尔积表示中，这四个函数写作 $\mathcal{E}^{\mathcal{C}} = \{(0,0),(1,1),(0,1),(1,0)\}$，第一和第二分量分别表示 $C=0$ 和 $C=1$ 的像. 显然，$(0,0)$ 与 $(1,1)$ 的均匀混合和 $(0,1)$ 与 $(1,0)$ 的均匀混合，在笛卡尔积的第一、第二分量上都诱导相同的边缘分布——这与它们诱导相同干预分布的说法一致. 然而，反事实陈述 "如果将 C 设为不同的值，E 会取不同的值" 只对 ID 与 NOT 的混合成立，而对 0 与 1 的混合不成立. 因此，反事实陈述不仅取决于噪声变量 N_E 各分量的边缘分布，还取决于笛卡尔积分量之间的统计依赖.

注意，形式上不同的两个 SCM 不仅可能诱导相同的干预分布，甚至可能蕴含相同的反事实陈述：给定赋值

$$E := f_E(C, N_E),$$

对 N_E 重新参数化显然无关紧要. 更明确地，可以令

$$E := \widetilde{f}_E(C, \widetilde{N}_E) = f_E(C, g^{-1}(\widetilde{N}_E)),$$

其中 g 是 N_E 值域上的某个双射，并重新定义噪声变量 $\widetilde{N}_E := g(N_E)$. 使用规范表示 (3.9)，我们消除了这个会混淆反事实讨论的额外自由度.

3.5 习题

问题 3.5（从 SCM 采样） 考虑 SCM

$$X := Y^2 + N_X, \tag{3.10}$$
$$Y := N_Y, \tag{3.11}$$

其中 $N_X, N_Y \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$. 从联合分布 (X,Y) 生成一个大小为 200 的独立同分布样本.

问题 3.6（条件分布） 证明式 (3.4) 中的 $P^{\mathfrak{C}}_{C|E=2}$ 是一个高斯分布：

$$C \mid E = 2 \sim \mathcal{N}\left(\frac{8}{17}, \sigma^2 = \frac{1}{17}\right).$$

问题 3.7（干预） 假设我们知道一个过程或者遵循 SCM

$$X := Y + N_X,$$
$$Y := N_Y,$$

其中 $N_X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ 和 $N_Y \sim \mathcal{N}(\mu_X, \sigma_Y^2)$，$\mu_X, \mu_Y$ 未知且 $\sigma_X, \sigma_Y > 0$；或者遵循 SCM

$$X := M_X,$$
$$Y := X + M_Y,$$

其中 $M_X \sim \mathcal{N}(\nu_X, \tau_X^2)$ 和 $M_Y \sim \mathcal{N}(\nu_Y, \tau_Y^2)$，$\nu_X, \nu_Y$ 未知且 $\tau_X, \tau_Y > 0$. 是否存在单个干预分布，使你能够区分这两个 SCM?

译注：源书问题 *3.7* 将 N_Y 的均值印为 μ_X，又把 μ_Y 列为未知参数；此处保留原式，未静默改为 μ_Y.

问题 3.8（有环 SCM） 我们曾提到，如果赋值具有有环结构，SCM 不一定在观测变量上诱导唯一分布. 有时没有解，有时解不唯一.

a) 首先考察一个诱导唯一解的例子. 考虑 SCM

$$X := 2 \cdot Y + N_X, \tag{3.12}$$
$$Y := 2 \cdot X + N_Y, \tag{3.13}$$

其中 $(N_X, N_Y) \sim P$，P 是任意分布. 计算 $\alpha, \beta, \gamma, \delta$，使得

$$X := \alpha N_X + \beta N_Y,$$
$$Y := \gamma N_X + \delta N_Y$$

给出该 SCM 的一个解 (X, Y, N_X, N_Y)，即该向量满足方程 (3.12) 和 (3.13). 该解可视为方程 (6.2) 的特例.

b) 考虑 SCM

$$X := Y + N_X,$$
$$Y := X + N_Y,$$

其中 $(N_X, N_Y) \sim P$. 证明：如果 P 关于 Lebesgue 测度有密度且可以因子分解，即 $N_X \perp\!\!\!\perp N_Y$，那么该 SCM 没有解 (X, Y, N_X, N_Y). 此外，构造一个分布 P 和一个求解该 SCM 的向量 (X, Y, N_X, N_Y).

Chapter 4

学习因果对模型

熟悉基于条件统计独立性、从观测数据发现因果关系的方法 [Pearl, 2009; Spirtes 等, 2000] 的读者，也许会对一章专门讨论仅有两个观测变量时的因果推断感到惊讶，因为在这种情况下不可能存在非平凡的条件独立关系. 本章介绍在仅有两个观测变量时进行因果推断所需的假设.

其中某些假设可能看起来过强而不够现实，但应当记住，即使不涉及因果问题，经验推断也需要强假设. 尤其在处理高维数据和小样本时，这是事实. 因此，过度简化的模型随处可见，而且已证明在许多学习情景中有所帮助.

这些假设种类多样，我们也确信清单并不完整. 当前研究仍处于探索巨大假设空间的阶段，这些假设使原因与结果可识别. 我们希望本章能够启发读者，继而添加其他可用于学习因果结构的、但愿是现实的假设.

第 4.1 节给出假设和理论可识别性结果；第 4.2 节说明如何在数据有限时利用这些结果识别结构.

4.1 结构可识别性

4.1.1 为何需要额外假设

在第 3 章中，我们介绍了通过函数赋值由原因 C 计算结果 E 的 SCM. 人们可能会问，数据生成过程的这一不对称性（即由 C 计算 E，而非反过来）是否仅从 $P_{C,E}$ 就可以看出来. 也就是说，两个变量 X, Y 的联合分布 $P_{X,Y}$ 能否告诉我们，它是由从 X 到 Y 还是从 Y 到 X 的 SCM 诱导的？换言之，结构能否从联合分布中识别出来？下面的已知结果表明，如果允许一般的 SCM，答案是 “不能”.

命题 4.1（图结构的非唯一性） 对两个实值变量的每个联合分布 $P_{X,Y}$，都存在 SCM

$$Y = f_Y(X, N_Y), \qquad X \perp\!\!\!\perp N_Y,$$

其中 f_Y 是可测函数，N_Y 是实值噪声变量.

证明： 类似于 Peters [2012，命题 2.6 的证明]，定义条件累积分布函数

$$F_{Y|x}(y) := P(Y \le y \mid X = x).$$

再定义

$$f_Y(x, n_Y) := F^{-1}_{Y|x}(n_Y),$$

其中 $F^{-1}_{Y|x}(n_Y) := \inf\{x \in \mathbb{R} : F_{Y|x}(x) \ge n_Y\}$. 然后令 N_Y 在 $[0,1]$ 上均匀分布且独立于 X. □

译注：源书广义逆表达式同时用 x 作条件值和下确界中的哑变量，存在变量遮蔽. 此处保留原记号；区分哑变量可写作 $\inf\{y : F_{Y|x}(y) \geq n_Y\}$，这是记号解释，并非源文另一个公式.

这一结果既可用于 $X = C, Y = E$，也可用于 $X = E, Y = C$，因此每个联合分布 $P_{X,Y}$ 都允许两个方向的 SCM. 正因如此，人们常认为，仅凭被动观测无法推断仅有两个观测变量之间的因果方向. 我们将在第 7 章看到，这一说法符合仅基于（条件）统计独立性进行因果推断的框架 [Spirtes 等, 2000；Pearl, 2009]. 在该框架中，因果结构 $X \to Y$ 与 $Y \to X$ 无法区分. 对仅有的两个变量，唯一可能的（条件）独立性只能以空集为条件；除非因果影响是非一般性的，否则这不会使 X, Y 独立.[1] 近年来，一些方法对这一观点提出了挑战：它们还利用联合分布中除条件独立性以外的信息. 这些方法依赖关于概率分布与因果性之间关系的额外假设.

第 4.1 节余下部分讨论在什么假设下可以从联合分布恢复图结构（结构可识别性）. 第 4.2 节随后介绍从有限数据集估计图的方法（结构识别）. 这些统计方法不需要以可识别性结果的证明为动机. 紧密遵循证明的方法往往不能高效利用数据.

4.1.2 假设类型概览

区分原因和结果的一种可能方法，是定义一类 “特别自然的” 条件分布 $P_{E|C}$[2]和边缘分布 P_C. 对于若干这样的类，理论结果表明：边缘分布 P_X 与条件分布 $P_{Y|X}$ 的 “一般性” 组合所诱导的联合分布，在交换 X, Y 后不能用同一个类描述. 这类陈述也称为可识别性结果，第 4.1 节余下部分将给出这样的例子.

例如，可以通过限制函数 f_E 的类别（见式 (3.2)）和 / 或式 (3.1)、(3.2) 中噪声分布的类别，来定义条件分布 $P_{E|C}$ 和边缘分布 P_C 的类别；第 4.1.3–4.1.6 节将讨论这一点. 从机器学习的角度看，这种方法似乎尤其自然，因为标准任务如回归与分类处处都在限制函数的复杂度. 注意，通过受限函数类推断因果方向，隐含假设噪声变量仍然独立，这与 SCM 的定义一致（见定义 3.1）. 在这个意义上，可以说这些方法使用图 2.2 所述的噪声独立性；但要记住，只有限制函数类之后，噪声独立性才使因果方向可识别（见命题 4.1）.

其他模型类可见 Sun 等 [2006]、Janzing 等 [2009b] 和 Comley 和 Dowe [2003]. 例如，Sun 等 [2006] 和 Janzing 等 [2009b] 考虑二阶指数模型；在这类模型中，$P_{E|C}$ 的对数密度除配分函数外是 e, c 的二次多项式，P_C 的对数密度则是 c 的二次多项式.

本部分以两个问题结束. 第一，应如何定义模型类，使其能够描述现实生活中合理比例的经验数据？第二，给定某个经验分布恰好只在一个方向上容许这样的模型，为什么该方向就应是因果方向？第一个问题实际上并非因果推断特有：构造描述观测变量之间关系的函数，总是需要拟合来自 “合理” 类别的函数. 第二个问题似乎是概率与因果性之间关系中最深刻的问题之一. 我们只能给出一些直观而模糊的想法，下面就来讨论.

首先给出一种直观动机，它与通常的机器学习为什么依赖受限模型类有关. 如第 1

[1] 注意，这种非一般性情形不应称为 “平凡”，因为非平凡的反事实影响可以与 $X \perp\!\!\!\perp Y$ 相容（见第 3.4 节）.

[2] 我们用记号 $P_{E|C}$ 简写条件分布的集合 $(P_{E|C=c})_c$，并隐含假设密度存在；换言之，$P_{E,C}$ 关于某个乘积测度绝对连续.

章所述，每当找到一个来自小函数类、能拟合有限数据的模型时，我们预期它也能拟合未来观测. 因此，找到小类中能够拟合数据的模型，是泛化到未来观测的关键. 从形式上说，学习因果模型与通常的学习情景有实质区别，因为前者旨在推断一个描述系统在干预下行为的模型，而不只是描述来自同一分布的观测. 因此，无法直接采用统计学习理论的论证来获得因果关系的学习理论. 尽管如此，我们相信，找到小类中的模型意味着——允许一定的错误概率——该模型在不同背景条件下也会成立. 我们还相信，在许多不同背景条件下成立的模型，比仅拟合单个数据集观测的模型更可能是因果模型（见第 7.1.6 节 “不同环境”）.

因此，通过限制模型类进行因果对推断与统计学习理论中的思想有一种模糊联系，但精确联系仍有待未来建立. 不应将上述使用小类因果模型的非正式论证误解为声称自然界中的因果关系确实简单. 我们是否经常能够用简单函数拟合数据，是一个完全不同的问题. 我们只是主张这样一种信念：如果存在拟合数据的简单函数，它也更有可能描述因果关系. 此外，我们将在第 4.1.9 节建立受限模型类与原因—机制独立性之间的一个联系. 为理解那些相当形式化的推导，我们先给出一个很不现实的玩具模型；我们认为它更像比喻，而不是严肃的例子.

第 2.1 节描述了这样一种思想：P_C 和 $P_{E|C}$ 对应自然界中两个独立机制，因此通常彼此不含信息（参见原则 2.1 和图 2.2 中间的框）. 自然，将 P_C 和 $P_{E|C}$ 假定为独立，即彼此不含信息，会引出究竟指何种信息的问题. 没有显而易见的方式将该假设形式化为一个可通过统计独立性检验来检查的条件. 这是因为我们讨论的是只能看到一个固定联合分布 $P_{C,E}$ 的情景，而不是一组分布；在后者中，我们可以检验假定原因的分布与给定原因时假定结果的分布是否以相依方式变化（这本质上是图 2.2 左框与中框之间的区别）.

为了用 SCM 的语言表达原因与机制的独立性，我们假设原因的分布应当独立于代表因果机制的函数和噪声分布. 注意，这同样是先验陈述，而非关于统计独立性的陈述. 它表示 f_E 和 P_{N_E} 不包含关于 P_C 的信息，反之亦然. 只有当所有从 E 到 C 描述 $P_{C,E}$ 的结构模型都违背这一独立性时，才能利用这一事实进行因果推断.

第 4.1.7 和 4.1.8 节描述两个玩具情景，在那里可以给出定义明确的独立与依赖概念. 最后，第 4.1.9 节描述 P_C 和 $P_{E|C}$ 独立性的一种形式化，它适用于更一般的情景，而不限于前述简单玩具情景. 在那里，依赖用算法互信息衡量，该概念基于 Kolmogorov 复杂度意义下的描述长度. 由于后者不可计算，应当将它视为哲学原则而不是方法. 它的实际意义有两个方面：第一，它可以启发新方法的开发；第二，可以用它为现有方法提供论证. 例如，独立性原则可以为基于先验限制模型类的推断方法提供论证；具体例子见第 4.1.9 节.

为粗略理解独立性如何与受限模型类相关，考虑一个思想实验：从 k 个不同的边缘分布构成的类别中随机选择 P_C；同样，假设从另一个由 ℓ 个不同条件分布组成的类别中选择 $P_{E|C}$. 这诱导 $k\ell$ 个不同的联合分布 $P_{C,E}$. 在一般情况下（除非这些类别的定义相当特殊），这会产生 $k\ell > k$ 个不同的边缘分布 P_E 和 $k\ell > \ell$ 个不同的条件分布 $P_{C|E}$. 因此，P_C 与 $P_{E|C}$ 的典型组合会诱导联合分布 $P_{E,C}$，而其 “反向边缘分布和条件分布” $P_E, P_{C|E}$ 不在原先的类别中，需要更大的模型类. 换言之，不论将可能的 P_C 和 $P_{E|C}$ 的集合选得多大，所诱导的 $P_{C|E}$ 和 P_E 集合更大. 这个思想实验更像一个比喻，因为它建

立在从有限集合随机选取的朴素图景上. 尽管如此，它支持这样一种信念：只要先验选定的小集合构造得合理，沿因果方向的边缘分布和条件分布就更可能容许来自该集合的描述.

译注：源文的严格计数不等式 $k\ell > k$ 和 $k\ell > \ell$ 还要求相应类别数大于 *1*；类别数为 *1* 的边界不能由严格不等式覆盖.

第 4.1.3–4.1.6 节描述对模型类作先验限制的模型假设，第 4.1.7–4.1.9 节则将独立性假设形式化. 其中第 4.1.9 节有特殊地位，因为它应被视为基础性原则，而非独立的推断方法.

4.1.3 具有非高斯加性噪声的线性模型

虽然具有高斯噪声的线性结构方程已得到广泛研究，较近的研究发现 [Kano 和 Shimizu, 2003; Shimizu 等, 2006; Hoyer 等, 2008a]，线性非高斯无环模型（LiNGAM）使因果推断出现新方法. 特别地，可以从观测数据区分 X 导致 Y 和 Y 导致 X. 所作假设是：除了一个加性噪声项之外，结果 E 是原因 C 的线性函数：

$$E = \alpha C + N_E, \qquad N_E \perp\!\!\!\perp C,$$

其中 $\alpha \in \mathbb{R}$（这是第 4.1.4 节将介绍的加性噪声模型的特例）. 以下结果说明这一假设足以识别原因和结果.

定理 4.2（线性非高斯模型的可识别性） 假设 $P_{X,Y}$ 容许线性模型

$$Y = \alpha X + N_Y, \qquad N_Y \perp\!\!\!\perp X, \tag{4.1}$$

其中 X, N_Y, Y 为连续随机变量. 那么，存在 $\beta \in \mathbb{R}$ 和随机变量 N_X，使得

$$X = \beta Y + N_X, \qquad N_X \perp\!\!\!\perp Y, \tag{4.2}$$

当且仅当 N_Y 和 X 均为高斯变量.

译注：源定理未显式排除 $\alpha = 0$. 若 $Y = N_Y$ 且 X 与非高斯 N_Y 独立，则取 $\beta = 0, N_X = X$ 也有反向模型；因此字面陈述需要非零系数等非退化条件. 原式保留，另见附录 *C.1* 的证明边界.

因此，只要 C 或 N_E 非高斯，就足以使因果方向可识别；例子见图 4.1. 让我们稍微详细地看看如何证明这一结果. 定理 4.2 是 Shimizu 等 [2006] 所引入模型类 LiNGAM 的双变量情形；他们利用独立分量分析（ICA）[Comon, 1994, 定理 11] 证明了该定理的多变量版本. ICA 的证明基于高斯分布的一种刻画，它由 Skitovič 和 Darmois 独立证明 [Skitovič, 1954, 1962; Darmois, 1953]；现在将其陈述如下.

定理 4.3（Darmois–Skitovič） 设 $X_1, \dots, X_d$ 是相互独立、非退化的随机变量（见附录 A.1）. 如果存在非零系数 $a_1, \dots, a_d$ 和 $b_1, \dots, b_d$（即对所有 i，$a_i \neq 0 \neq b_i$），使得两个线性组合

$$l_1 = a_1 X_1 + \cdots + a_d X_d,$$
$$l_2 = b_1 X_1 + \cdots + b_d X_d$$

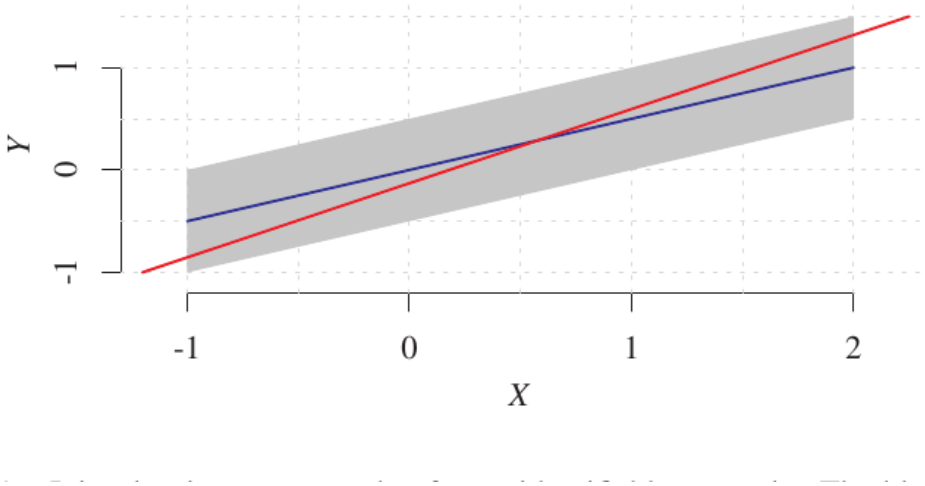


图 4.1: 一个可识别例子中 X, Y 的联合密度. 蓝线为正向模型 $Y := 0.5 \cdot X + N_Y$ 对应的函数，其中 X 和 N_Y 均匀分布；灰色区域表示 (X, Y) 的密度支撑. 定理 4.2 表明，由于 (X, N_Y) 的分布非高斯，不可能存在有效的反向模型. 由 (b, c) 表征的红线是最小化 $\mathbb{E}[X - bY - c]^2$ 的最小二乘拟合. 它不是有效的反向模型 $X = bY + c + N_X$，因为所得噪声 N_X 不独立于 Y（对于不同的 Y 值，N_X 的支撑大小不同）.

相互独立，那么每个 X_i 都服从正态分布.

事实表明，定理 4.2 中所述的双变量版本可以作为 Darmois–Skitovič 定理的一个简短而直接的推论加以证明；为说明起见，我们在附录 C.1 附上了这个证明. 此外，可以证明双变量 SCM 的可识别性可以推广到多变量 SCM 的可识别性 [Peters 等, 2011b]. 利用这一结果，LiNGAM 的多变量可识别性便可由定理 4.2 得出.

具有非高斯加性噪声的线性模型还可用于一个从机器学习角度看不常见、但从理论物理角度看很有趣的问题：从数据估计时间箭头. Peters 等 [2009b] 表明，自回归模型时间可逆，当且仅当噪声变量服从正态分布. 为探索经验时间序列的不对称性，他们拟合两个自回归模型来推断时间方向：一个按通常方式从过去到未来，另一个从未来到过去. 在他们的实验中，前一方向的噪声变量确实倾向于比反向时间中的噪声变量更加独立（参见第 4.2.1 节）. Bauer 等 [2016] 将该思想推广到多变量时间序列. Janzing [2010] 将这种观测到的不对称性与热力学时间箭头联系起来，这表明本书讨论的原因与结果的不对称性也与统计物理的基本问题有关.

4.1.4 非线性加性噪声模型

现在介绍*加性噪声模型*（additive noise model，ANM）. 这是对 SCM 类别限制得不那么极端的一种方式，但限制仍足够强，使因果对推断成为可能.

定义 4.4（ANM） 如果存在可测函数 f_Y 和噪声变量 N_Y，使得

$$Y = f_Y(X) + N_Y, \qquad N_Y \perp\!\!\!\perp X, \tag{4.3}$$

则称联合分布 $P_{X,Y}$ 容许一个从 X 到 Y 的 ANM. 略作术语上的扩展，若式 (4.3) 成立，我们也称 $P_{Y|X}$ 容许 ANM.

下面的定理说明，“一般” 而言，一个分布不会同时在两个方向上容许 ANM.

定理 4.5（ANM 的可识别性） 就本定理而言，如果 N_Y 和 X 具有严格为正的密度 p_{N_Y} 和 p_X，并且 f_Y, p_{N_Y}, p_X 三次可微，我们就称式 (4.3) 的 ANM 是光滑的.

假设 $P_{Y|X}$ 容许一个从 X 到 Y 的光滑 ANM，并且存在 $y \in \mathbb{R}$，使得除至多可数多个 x 值外，

$$(\log p_{N_Y})''(y - f_Y(x)) f_Y'(x) \neq 0. \tag{4.4}$$

那么，使得所得到的联合分布 $P_{X,Y}$ 容许一个从 Y 到 X 的光滑 ANM 的对数密度 $\log p_X$ 集合，包含于一个三维仿射空间中.

证明：（思路概要；细节见 Hoyer 等 [2009].）从 Y 到 X 的 ANM 给出

$$p(x, y) = p_Y(y) p_{N_X}(x - f_X(y)), \tag{4.5}$$

它蕴含

$$\log p(x, y) = \log p_Y(y) + \log p_{N_X}(x - f_X(y)).$$

可以证明，$\log p(x, y)$ 随后满足微分方程

$$\frac{\partial}{\partial x}\left[\frac{\partial^2 \log p(x, y)/\partial x^2}{\partial^2 \log p(x, y)/(\partial x \partial y)}\right] = 0. \tag{4.6}$$

另一方面，从 X 到 Y 的 ANM 写作

$$p(x, y) = p_{N_X}(x) p_{N_Y}(y - f_Y(x)). \tag{4.7}$$

对式 (4.7) 取对数得到

$$\log p(x, y) = \log p_X(x) + \log p_{N_Y}(y - f_Y(x)). \tag{4.8}$$

将式 (4.6) 应用于式 (4.8)，得到关于 $\log p_X$ 的三阶导数的微分方程，它由 f_X 和 $\log p_{N_Y}$ 的一阶、二阶和三阶导数表示. 因此，f_X 和 p_{N_E}（它们是条件分布 $P_{Y|X}$ 的性质）确定 $\log p_X$，只留下三个自由参数：对于任意点 ν，$\log p_{N_X}(\nu)$、$(\log p_{N_X})'(\nu)$ 和 $(\log p_{N_X})''(\nu)$. □

译注：源书式 *(4.7)* 使用 $p_{N_X}(x)$，下一式 *(4.8)* 写 $p_X(x)$，证明末还有 f_X, p_{N_E}, p_{N_X} 的方向记号差异. 本段按源式保留，不把这些符号差异当作已澄清的恒等替换.

定理 4.5 给出 “一般” 情形下的可识别性；这里 “一般” 由式 (4.4) 及三维子空间等复杂条件刻画. 当 p_X 和 p_{N_Y} 均为高斯时，有一个简单得多的可识别性陈述：只有线性函数 f 才能生成在反向容许 ANM 的分布［见 Hoyer 等, 2009，推论 1］. 图 4.2 展示两个在两个方向都容许加性噪声模型的 “非一般性” 双变量分布：第一种是显然的双变量高斯情形；第二种较为复杂，需要 p_X 与 N_X 之间进行精细调节［Mooij 等, 2016］.

为了将定理 4.5 与因果语义联系起来，先假设我们先验地知道原因与结果的联合分布 $P_{X,Y}$ 容许一个从 C 到 E 的 ANM，但不知道 $X = C, Y = E$ 是否成立，还是恰好相

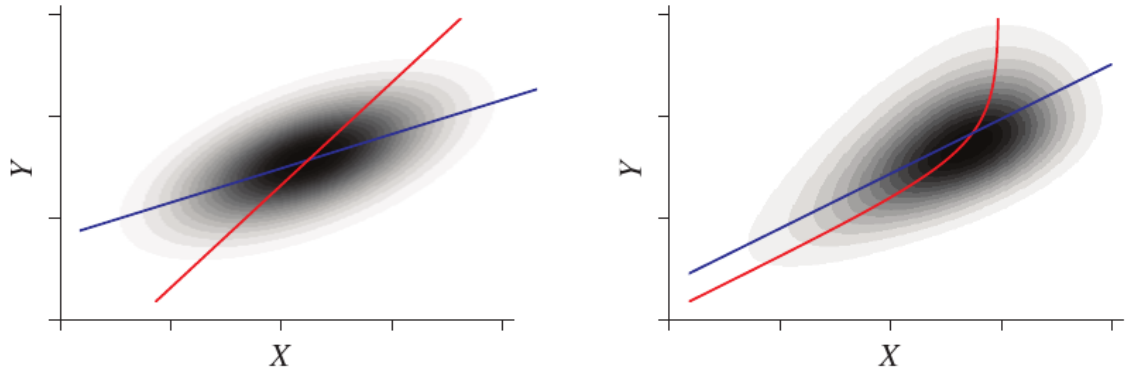


图 4.2: 两个不可识别例子中 X, Y 的联合密度. 左图为线性高斯情形; 右图为稍复杂的例子, 其中函数、输入分布和噪声分布的参数经过 "精细调节" (后一幅图基于核密度估计). 蓝色函数 f_Y 对应正向模型 $Y := f_Y(X) + N_Y$, 红色函数 f_X 对应反向模型 $X := f_X(Y) + N_X$.

反. 定理 4.5 表明, 一般而言不会存在从 E 到 C 的 ANM, 因此我们可以容易地判定哪个变量是原因 C.

不过, 一般来说, 自然界中的条件分布 $P_{E|C}$ 并未受到如此强的限制, 不一定容许 ANM. 那么, 是否可能由 P_C 和 $P_{E|C}$ 诱导一个容许从 E 到 C 的 ANM 的联合分布 $P_{C,E}$? (此时我们会推断出错误的因果方向.) 我们在第 4.1.9 节论证: 如果 P_C 和 $P_{E|C}$ 是独立选择的, 这种情形不太可能发生.

4.1.5 离散加性噪声模型

加性噪声不仅可以为实值变量定义, 也可以为在某个环中取值的任意变量定义. Peters 等 [2010, 2011a] 为环[3] $\mathbb{Z}$ 和 $\mathbb{Z}/m\mathbb{Z}$ 引入 ANM; 它们分别是整数集合和模 $m \in \mathbb{Z}$ 的整数集合. 在后一个环中, 我们将除以 m 后具有相同余数的数视为同一个数. 例如, 整数 132 和 4 除以 8 后都有余数 4, 我们写作 $132 \equiv 4 \pmod 8$. 当某个定义域具有循环结构时, 这样的模运算可能是恰当的. 例如, 如果考虑一年中的日期, 我们可能希望 12 月 31 日与 1 月 1 日之间的距离, 等于 8 月 25 日与 8 月 26 日之间的距离.

与连续情形一样, 可以证明一般情况下联合分布至多在一个方向上容许 ANM. 以下结果考虑环 $\mathbb{Z}$ 的例子.

定理 4.6 (离散 ANM 的可识别性) 假设分布 $P_{X,Y}$ 容许从 X 到 Y 的 ANM $Y = f(X) + N_Y$, 并且 X 或 Y 中至少一个具有有限支撑. $P_{X,Y}$ 容许从 Y 到 X 的 ANM, 当且仅当存在互不相交的分解 $\bigcup_{i=0}^{l} C_i = \operatorname{supp} X$, 使得以下条件 a)、b)、c) 成立:

a) 各个 C_i 是彼此平移得到的版本:

$$\forall i \; \exists d_i \geq 0 : \quad C_i = C_0 + d_i,$$

且 f 是分段常数: 对所有 i, $f|_{C_i} \equiv c_i$.

[3] 在环中, 我们可以进行加法和乘法, 不过后者不一定有逆运算.

b) C_i 上的概率分布是彼此平移并缩放得到的版本，平移常数与上面相同：对于 $x \in C_i$，$P(X = x)$ 满足

$$P(X = x) = P(X = x - d_i) \cdot \frac{P(X \in C_i)}{P(X \in C_0)}.$$

c) 集合 $c_i + \operatorname{supp} N_Y := \{c_i + h : P(N_Y = h) > 0\}$ 彼此不相交.

（由对称性，对于 Y 的支撑也存在满足相同条件的分解.）图 4.3 给出一个在两个方向都容许 ANM 的例子 [Peters 等, 2011a]．

对于模 m 的离散 ANM，也有类似结果. 细节参见 Peters 等 [2011a]；不过我们想指出均匀噪声分布具有特殊作用：若 $Y \equiv f(X)+N_Y \pmod m$ 的噪声变量在 $\{0,\dots,m-1\}$ 上均匀分布，那么 X, Y 独立，因此它也容许从 Y 到 X 的 ANM.

离散 ANM 对底层过程施加了很强的假设，在实践中常被违背. 与连续情形一样，我们想论证：如果过程在一个方向上容许离散 ANM，推断该方向为因果方向可能是合理的（另见第 4.1.9 节）.

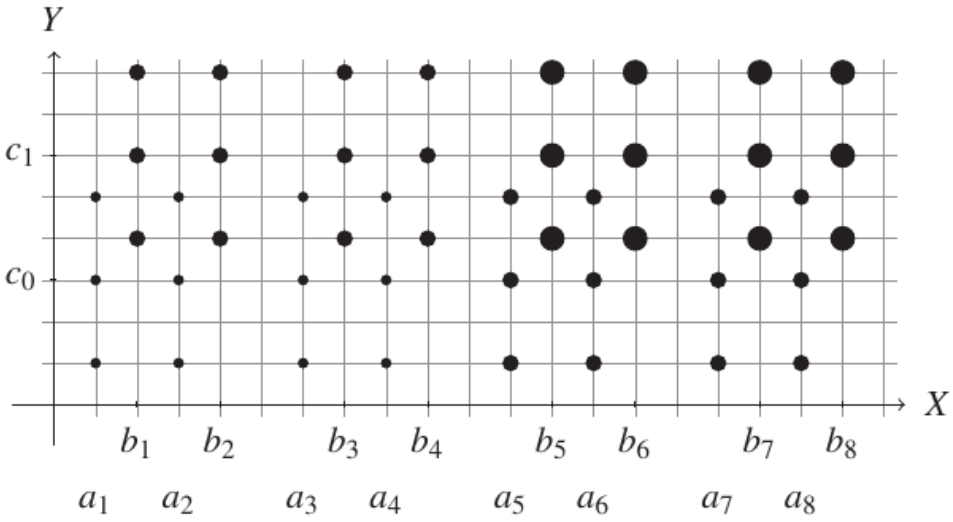


图 4.3: 只有精心选择的参数才容许两个方向的 ANM（圆的半径对应概率值）；见定理 4.6. 定理中所述的集合为 $C_0 = \{a_1, a_2, \dots, a_8\}$ 和 $C_1 = \{b_1, b_2, \dots, b_8\}$. 函数 f 在 C_0 和 C_1 上分别取值 c_0 和 c_1.

4.1.6 后非线性模型

Zhang 和 Hyvärinen [2009] 分析了一个比第 4.1.4 节所述更一般的模型类；较早文献另见 Zhang 和 Chan [2006].

定义 4.7（后非线性模型） 如果存在函数 f_Y, g_Y 和噪声变量 N_Y，使得

$$Y = g_Y(f_Y(X) + N_Y), \qquad N_Y \perp\!\!\!\perp X, \tag{4.9}$$

则称分布 $P_{X,Y}$ 容许后非线性模型.

以下结果基本表明，除某些“罕见”的非一般性情形外，后非线性模型至多在一个方向存在.[4]

定理 4.8（后非线性模型的可识别性） 设 $P_{X,Y}$ 如式 (4.9) 所示容许从 X 到 Y 的后非线性模型，且 p_X, f_Y, g_Y 三次可微. 那么，只有当 p_X, f_Y, g_Y 彼此调适、使其满足 Zhang 和 Hyvärinen [2009] 所描述的一个微分方程时，它才容许从 Y 到 X 的后非线性模型.

4.1.7 信息几何因果推断

为了说明如何将 $P_{E|C}$ 与 P_C 之间的独立性形式化，本节介绍信息几何因果推断 (IGCI). IGCI，尤其是此处描述的简单版本，是一个高度理想化的玩具情景，它很好地说明了一个方向上的独立性如何蕴含另一个方向上的依赖 [Daniušis 等, 2010；Janzing 等, 2012]. 它依赖一个（显然很强的）假设：X, Y 在两个方向都具有确定性关系，即

$$Y = f(X) \quad \text{且} \quad X = f^{-1}(Y).$$

换言之，式 (3.2) 中的噪声变量是常数. 此时，第 4.1.2 节描述的原因与机制独立性原则归结为 P_X 与 f 的独立性. 值得注意的是，这种独立性蕴含 P_Y 与 f^{-1} 之间的依赖. 为说明这一点，我们考虑 Daniušis 等 [2010] 所给更一般情形的以下特例.

定义 4.9（IGCI 模型） 如果满足下列条件，就称 $P_{X,Y}$ 满足从 X 到 Y 的 IGCI 模型：$Y = f(X)$，其中 f 是 $[0,1]$ 上严格单调的微分同胚，[5]满足 $f(0) = 0, f(1) = 1$. 此外，P_X 具有严格为正的连续密度 p_X，使以下“独立性条件”成立：

$$\operatorname{cov}[\log f', p_X] = 0, \tag{4.10}$$

其中 $\log f'$ 和 p_X 被视为赋予均匀分布的概率空间 $[0,1]$ 上的随机变量.[6]

注意，式 (4.10) 中的协方差明确写为

$$\begin{aligned}\operatorname{cov}[\log f', p_X] &= \int_0^1 \log f'(x) p_X(x)\,\mathrm{d}x - \int_0^1 \log f'(x)\,\mathrm{d}x \int_0^1 p_X(x)\,\mathrm{d}x \\ &= \int_0^1 \log f'(x) p_X(x)\,\mathrm{d}x - \int_0^1 \log f'(x)\,\mathrm{d}x.\end{aligned}$$

以下结果由 Daniušis 等 [2010] 和 Janzing 等 [2012] 给出.

定理 4.10（IGCI 模型的可识别性） 假设分布 $P_{X,Y}$ 容许从 X 到 Y 的 IGCI 模型. 那么逆函数 f^{-1} 满足

$$\operatorname{cov}[\log(f^{-1})', p_Y] \geq 0, \tag{4.11}$$

当且仅当 f 是恒等映射时等号成立.

[4]这里的“罕见”不应误解为只有有限多个例外.

[5]如果函数可微且双射，并且其逆函数可微，则称其为微分同胚.

[6]这一观点可能令人意外，但回忆一下，随机变量被定义为概率空间上的可测函数. 此处 $\log f'$ 和 p_X 都是 $x \in [0,1]$ 的函数，因此它们是共同概率空间 $[0,1]$ 上的随机变量. 因而，$[0,1]$ 上的任意分布都定义这两个随机变量的联合分布.

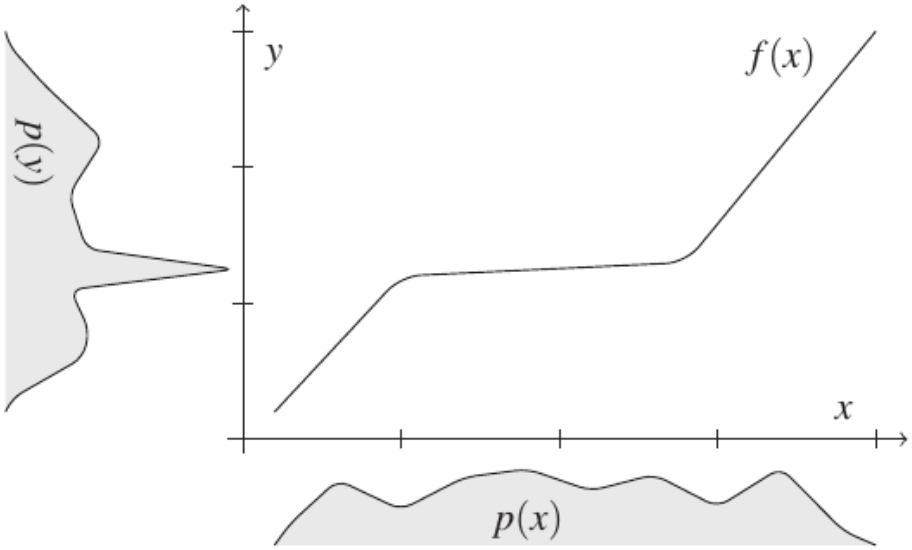


图 4.4: IGCI 思想的可视化：p_Y 的峰值倾向于出现在 f 斜率小、f^{-1} 斜率大的区域（前提是 p_X 独立于 f 选取）. 因此，p_Y 包含关于 f^{-1} 的信息. IGCI 可以推广到不可微函数 f [Janzing 等, 2015] .

换言之，除平凡情形 $f = \mathrm{id}$ 外，$\log f'$ 与 p_X 不相关蕴含 $\log(f^{-1})'$ 与 p_Y 正相关. 图 4.4 说明了这一点. 可以证明 [Janzing 和 Schölkopf, 2015]，f' 与 p_X 不相关（即去掉对数后的式 (4.10) 类比式）蕴含 $(f^{-1})'$ 与 p_Y 正相关；但 IGCI 使用对数导数，因为这样可以作出多种信息论解释 [Janzing 等, 2012] . 为论证式 (4.10)，Janzing 等 [2012] 描述了一个模型：f 独立于 P_X 随机生成，并表明此时式 (4.10) 以高概率近似成立.

但应强调，这类论证总是针对过度简化、不太可能描述真实情形的模型. 注意，IGCI 很容易推广到向量值变量之间的双射关系（Daniušis 等 [2010，第 3 节] 已经这样描述），但在经验数据中双射确定性关系很少见. 因此，IGCI 只提供一个玩具情景：借助近似独立性假设，在该情景下可以进行因果对推断. IGCI 的假设也被用来解释为什么半监督学习的性能依赖于第 5.1 节所述的因果方向 [Janzing 和 Schölkopf, 2015] . 式 (4.10) 绝非意在作为原因与机制独立性的正确形式化，我们也不相信存在唯一的形式化. 例如，Sgouritsa 等 [2015] 提出一种 “无监督逆回归” 技术，试图从 P_X 预测 $P_{Y|X}$，并从 P_Y 预测 $P_{X|Y}$；随后他们提出表现较差的方向是因果方向. 因而，该方法将 “独立性” 解释为使这类无监督预测不可能.

4.1.8 迹方法

Janzing 等 [2010] 和 Zscheischler 等 [2011] 针对 C, E 是通过线性 SCM 耦合的高维变量的情形，描述了与 IGCI 有关的 P_C 和 $P_{E|C}$ 之间的独立性：

定义 4.11（迹条件） 设变量 X, Y 分别在 $\mathbb{R}^d, \mathbb{R}^e$ 中取值，满足线性模型

$$Y = AX + N_X, \qquad N_X \perp\!\!\!\perp X, \tag{4.12}$$

其中 A 是 $e \times d$ 的结构系数矩阵. 如果协方差矩阵 Σ_{XX} 与 A 在以下意义上 “独立”，则

称 $P_{X,Y}$ 满足从 X 到 Y 的迹条件：

$$\tau_e(A\Sigma_{XX}A^T) = \tau_d(\Sigma_{XX})\tau_e(AA^T), \tag{4.13}$$

其中 $\tau_k(B) := \mathrm{tr}(B)/k$ 表示矩阵 B 的归一化迹.

译注：源定义把 $Y = AX$ 情形中的加性噪声记为 N_X，此处沿用源记号，不自动改为 N_Y.

一个违背迹条件的简单例子是这样的矩阵 A：它压缩 Σ_{XX} 中对应大特征值的所有特征向量，并拉伸对应小特征值的特征向量. 这无疑表明 A 不是独立于 Σ_{XX} 选取的. 粗略地说，式 (4.13) 描述了 Σ_{XX} 的特征值与 A 改变对应特征向量长度的因子之间的不相关性. 更形式化地，可以用一个 d, e 很大的生成模型为式 (4.13) 提供论证：在该模型中，Σ_{XX} 和 A 根据适当的（旋转不变）先验概率独立随机选取. 那么它们以高概率近似满足式 (4.13) [Besserve 等，准备中].

对于确定性可逆关系，因果方向是可识别的.

定理 4.12（利用迹条件的可识别性） 设 X, Y 都是 d 维变量，满足 $Y = AX$，其中 A 可逆. 如果从 X 到 Y 的迹条件 (4.13) 成立，那么反向模型 $X = A^{-1}Y$ 满足

$$\tau_d(A^{-1}\Sigma_{YY}A^{-T}) \leq \tau_d(\Sigma_{YY})\tau_d(A^{-1}A^{-T}),$$

当且仅当 A 的所有奇异值具有相同绝对值时等号成立.

译注：源定理未显式排除 $\Sigma_{YY} = 0$；此时所列等式可在 A 奇异值不同的情况下仍成立，故“当且仅当还需非退化条件. 后面的商式又使用 $A_X\Sigma_{YY}A_X^T$ 及 $A_X = A_Y^{-1}$，方向记号照源保留，解释尚待核实.

证明： 将 Janzing 等 [2010] 的定理 2 应用于 $n := m := d$，并注意到只要 Z 是严格为正且几乎处处不是常数的随机变量，就有 $\mathrm{cov}[Z, 1/Z] < 0$，便得到证明. □

因此，在一般情况下，反向的迹条件被违背，而且等式被违背的符号始终相同.

对于有噪声的关系，目前不知道类似定理 4.12 的陈述. 仍然可以检验式 (4.13) 是否在某个方向近似成立，并推断该方向为因果方向. 此时，从 Y 到 X 的因果模型的结构矩阵不再由 A^{-1} 给出. 我们引入记号 A_X 表示从 X 到 Y 的模型，A_Y 表示从 Y 到 X 的模型. 确定性情形特别好的地方在于，已知商

$$\frac{\tau(A_X\Sigma_{YY}A_X^T)}{\tau(A_XA_X^T)\tau(\Sigma_{YY})}$$

小于 1，因为 $A_X = A_Y^{-1}$.

对于式 (4.10)、(4.13) 以及本书提及的其他独立性条件，其理论论证依赖高度理想化的生成模型（例如，式 (4.13) 的一种论证采用一个模型，其中原因的协方差矩阵由旋转不变先验生成 [Janzing 等, 2010]）. 不过，人们有理由希望，理想化假设被违背不一定会破坏因果推断方法. Beuchet 椅的比喻有助于说明这一点. 首先考虑一个观察视点在球面上均匀选取的情景. 显然，这一视点不包含关于物体朝向的信息. 在这个意义上，均匀先验将一种“独立性”假设形式化. 此时只有可忽略的一小部分角度会产生椅子错觉. 容易看出，要得到这一结论，选择视点时不需要严格均匀. 任何随机选择，只要

其先验不集中于这一小部分特殊角度，都会得到相同结果. 换言之，关于典型观察者会看到什么的结论，对底层独立性假设的违背是稳健的. 因此，讨论因果推断中的理想化假设时，重点应是违背这些假设会在多大程度上破坏推断方法，而不是解释它们为什么过于理想化.

4.1.9 作为可能基础的算法信息论

本节描述一个独立性原则：尽管它依赖定义明确的数学形式体系，却不清楚如何在实践中应用. 因此，它介于一方面第 2.1 节关于因果推断基础的非正式哲学讨论，另一方面第 4.1.3–4.1.8 节基于相当具体模型假设、关于原因和结果可能存在的不对称性的具体结果之间.

对于比第 4.1.7 和 4.1.8 节所考虑情形更一般的模型，要将 P_E 和 $P_{C|E}$ 彼此不含信息形式化是有挑战性的. 这需要一个涉及随机变量以外对象的信息概念，因为 P_E 和 $P_{C|E}$ 本身不是随机变量，而是描述随机变量的分布. 一个有趣的信息概念由 Kolmogorov 复杂度给出，下面作简要说明.

首先介绍 Kolmogorov 复杂度：考虑通用图灵机 T，即一种计算机抽象；它是理想化的，因为它可以访问无限的内存空间. 对任意二进制串 s，将 $K_T(s)$ 定义为使 T 输出 s 然后停止的最短程序[7]的长度，该程序记为 s^* [Solomonoff, 1964; Kolmogorov, 1965; Chaitin, 1966; Li 和 Vitányi, 1997]. 可以将 s^* 称为 s 的最短压缩，但应记住 s^* 包含 T 执行解压所需的全部信息. 因而

$$K_T(s) := |s^*|,$$

其中 $|\cdot|$ 表示二进制字的位数. 这定义了关于给定图灵机 T 的、不依赖概率的信息内容概念. 下文固定某个 T，因此省略下标. 尽管 $K(s)$ 不可计算，即不存在从 s 计算 $K(s)$ 的算法 [Li 和 Vitányi, 1997]，它仍可如本节那样用于将概念性思想形式化.

给定 t 时 s 的条件算法信息记为 $K(s \mid t)$，定义为以串 t 为输入、生成输出 s 后停止的最短程序的长度. 接着可以将互信息定义为[8]

$$I(s : t) := K(s) - K(s \mid t^*).$$

特别地，有 [Chaitin, 1966]:

$$I(s : t) \stackrel{+}{=} K(s) + K(t) - K(s, t), \tag{4.14}$$

其中符号 $\stackrel{+}{=}$ 表示等式只在相差常数的意义下成立，即存在一个长度可以由与 s, t 长度无关的量界定的误差项. 为定义对 (s, t) 的 Kolmogorov 复杂度 $K(s, t)$，先对串进行某种枚举，再使用 $\mathbb{N}$ 与 $\mathbb{N} \times \mathbb{N}$ 之间的标准双射，构造串与串对之间的简单双射.

[7]程序由采用前缀无关编码的二进制字给出，即没有任何程序代码是另一个的前缀. 否则就需要额外符号标记代码结束.

[8]注意，以 t^* 而不是 t 为条件会产生差别，因为不存在从 t 计算 t^* 的算法（反过来则可以）；因此作为输入，t^* 可能比 t 更有价值. 事实表明，$K(s \mid t^*)$ 比 $K(s \mid t)$ 更类似于条件 Shannon 熵.

式 (4.14) 的一个简单解释是：算法互信息量化了联合压缩 s,t 相对于分别压缩时所节约的内存空间. Janzing 和 Schölkopf [2010] 认为，二进制描述 s,t 具有显著互信息的两个对象很可能存在因果联系. 换言之，正如随机变量之间的统计依赖表明因果联系（见原则 1.1），对象之间的算法依赖也表明对象之间的因果联系. 例如，观察到不同公司生产的两件设计相似的 T 恤，可能表明一家公司抄袭了另一家. 的确，只要先约定以“适当”方式将图案编码成二进制字，再约定一台“适当”的图灵机，现实中的图案相似性就可以用算法互信息描述. 关于“适当”究竟意味着什么这一困难问题，另见 Janzing 等 [2016] 引言中对“相对因果性”的简短讨论.

Janzing 和 Schölkopf [2010] 及 Lemeire 和 Janzing [2013] 针对多变量因果结构提出了条件分布算法独立性原则，但它在双变量情形下就已产生非平凡的推论.

对于作为原因和结果的两个变量 C,E，我们假设 P_C 和 $P_{E|C}$ 分别容许由二进制串 s,t 作有限描述. 在参数化情形中，s,t 可以描述相应参数空间中的点. 也可以把 s,t 看作程序，它们对所有具有有限描述长度的 c,e 计算 $p(c)$ 和 $p(e \mid c)$. 然后我们用 $I(P_C : P_{E|C})$ 表示 $I(s:t)$，并作如下假设：

原则 4.13（算法独立的条件分布） P_C 和 $P_{E|C}$ 在算法上独立，即

$$I(P_C : P_{E|C}) \stackrel{+}{=} 0, \tag{4.15}$$

或等价地，

$$K(P_{C,E}) \stackrel{+}{=} K(P_C) + K(P_{E|C}). \tag{4.16}$$

式 (4.15) 和式 (4.16) 的等价性是直接的，因为描述对 $(P_C, P_{E|C})$ 等价于描述联合分布 $P_{C,E}$. 原则 4.13 的思想是，P_C 和 $P_{E|C}$ 是自然界中没有因果联系的对象. 这当然是理想化假设，但在 X 导致 Y 或 Y 导致 X 的情形中，它提示我们：只要 P_X 与 $P_{Y|X}$ 之间的算法依赖比 $P_{X|Y}$ 与 P_Y 之间的算法依赖弱，就推断 $X \to Y$. 不过，要将其应用于经验数据，除了算法互信息不可计算之外，还存在有限数据无法确定 $P_{X,Y}$ 的问题.

尽管存在这些问题，原则 4.13 仍有助于为实际因果推断方法提供论证；下面以 ANM 为例说明. Janzing 和 Steudel [2010] 认为，SCM $Y := f_Y(X) + N_Y$ 蕴含 $y \mapsto \log p(y)$ 的二阶导数由 $(x,y) \mapsto \log p(x \mid y)$ 的偏导数确定. 因而，知道 $P_{X|Y}$ 就可以（达到某种精度）对 P_Y 作简短描述. 只要 $K(P_Y)$ 大于这一少量信息，Janzing 和 Steudel [2010] 就得出应当拒绝 $Y \to X$ 的结论，因为 P_Y 和 $P_{X|Y}$ 在算法上相依.

对于任何给定数据集，我们不能仅因存在从 Y 到 X 的 ANM，就保证 $K(P_Y)$ 足够大以拒绝 $Y \to X$. 但是，当我们将基于 ANM 原则的推断应用于大量不同分布时，我们知道大多数分布 P_Y 足够复杂（因为低复杂度分布的集合很小），足以支持拒绝那些在相反方向诱导 ANM 的因果模型. 此外，图 5.4 的左右两图显示两个简单玩具例子，在那里仅观察 P_X 就会提示对联合分布 $P_{X,Y}$ 作一个简单猜测. 事实上，如 Janzing 和 Schölkopf [2010，式 (27) 后的注记] 对左图所示，这相当于 P_X 与 $P_{Y|X}$ 之间的算法依赖.

译注：本段源文将所存在的 *ANM* 方向写为 Y 到 X，又讨论能否拒绝 $Y \to X$；上下文方向可能有误. 本译稿照录，不据此静默反转箭头.

还应指出，式 (4.15) 蕴含

$$K(P_C) + K(P_{E|C}) \stackrel{+}{=} K(P_{C,E}) \stackrel{+}{\leq} K(P_E) + K(P_{C|E}). \tag{4.17}$$

等式成立是因为描述 $P_{C,E}$ 等价于描述对 $(P_C, P_{E|C})$，而后者并不比分别描述边缘分布与条件分布更短. 不等式成立是因为 P_E 和 $P_{C|E}$ 也决定 $P_{C,E}$. 换言之，条件分布的独立性蕴含：沿因果方向对联合分布的描述比沿反因果方向的描述更短.[9]

从最小描述长度原则 [Grünwald, 2007] 和奥卡姆剃刀的角度看，这一推论也很自然. 但注意，条件 $K(P_C) + K(P_{E|C}) \stackrel{+}{\leq} K(P_E) + K(P_{C|E})$ 严格弱于式 (4.15)，因为 $P_{C,E}$ 的最短描述可能不使用这两个可能因子分解中的任何一个；例如存在隐藏共同原因时就可能发生这种情况 [Janzing 和 Schölkopf, 2010，第 16 页].

原则 6.53 将原则 4.13 推广到多变量情形.

4.2 结构识别方法

现在介绍如何利用第 4.1 节的可识别性结果进行因果发现的不同思路，即从有限数据集估计图的方法. 这些统计问题具有挑战性，可以通过许多不同方式处理. 我们着重介绍方法思想，并不声称所介绍的方法能最高效地利用数据. 未来研究很可能产生新的成功方法. 我们只讨论少数例子，主要是对其性能有较充分经验的方法.

4.2.1 加性噪声模型

基于定理 4.5 中 ANM 可识别性的因果学习方法，主要参见多变量章节（第 7.2 节）. 这里概述两种方法，并不声称它们是最优的. 第一种方法检验残差的独立性，是“回归后进行独立性检验”（RESIT）算法的一个特例（见第 7.2 节）.

1. 用 X 回归 Y，即用某种回归技术将 Y 写作 X 的函数 $\widehat{f}_Y$ 加上某个噪声.
2. 检验 $Y - \widehat{f}_Y(X)$ 是否独立于 X.
3. 交换 X, Y 的角色，重复上述过程.
4. 如果一个方向接受独立性而另一方向拒绝独立性，则推断前一个方向为因果方向.

图 4.5 在模拟数据集上展示了这一过程；其底层分布见图 4.1. 至少在连续情形下，前两步是机器学习与统计学中的标准问题（见附录 A.1 和 A.2）；额外挑战在于二者相互耦合：$\widehat{f}_Y$ 偏离 f_Y 可能掩盖或产生噪声与输入变量之间的依赖. 一般而言，任何基于估计残差的检验都可能失去第一类错误控制. 一个可能的解决办法是样本分割 [Kpotufe 等, 2014]. 此外，重要的是选择考虑高阶统计量而非只检验相关性的独立性检验. 任何包含线性分量和截距、并最小化二次误差的回归技术都会产生不相关的噪声.[10]

[9] 检验不等式 (4.17) 左侧是否小于右侧，并不是检验独立性的唯一选择：只要两个串算法独立，分别对它们应用复杂度为 $O(1)$ 的函数，仍会得到两个（可能更简单的）算法独立串 [Janzing 和 Schölkopf, 2010，引理 6]. 因此，原则上可以在事先不知道串复杂度的情况下拒绝算法独立性.

[10] 可以通过以下标准几何图像容易地看出这一点：在具有有限方差的中心化随机变量空间中，$\mathrm{cov}[\cdot,\cdot]$ 定义内积. 向量 $Y - \alpha X$ 与 X 正交时，其长度最小.

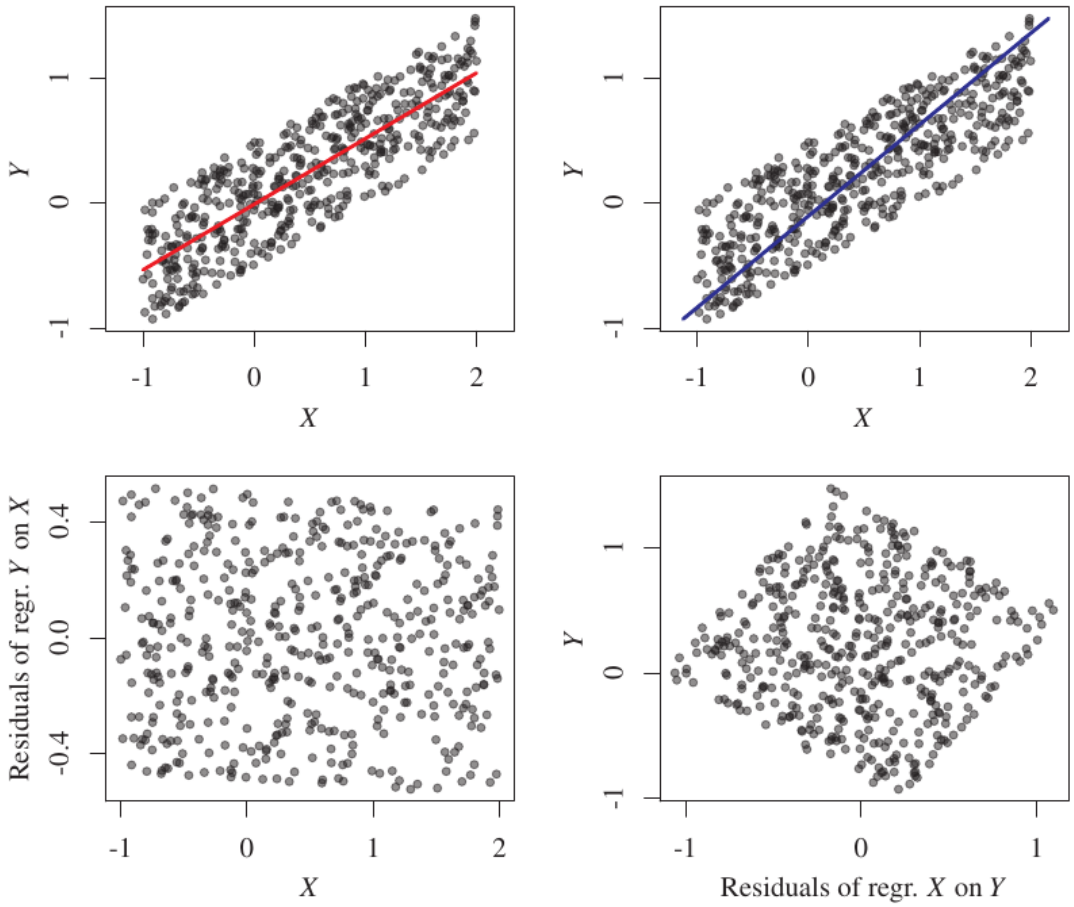


图 4.5: 给定底层分布的样本后，分别沿 $X \to Y$（左）和 $Y \to X$（右）进行线性回归. 上排为拟合函数，下排为相应残差. 只有 $X \to Y$ 方向产生独立残差；另见图 4.1. 原图 residuals of regression 为回归残差.

实践中例如可以使用 Hilbert–Schmidt 独立性准则（HSIC）[Gretton 等, 2008]，附录 A.2 将简要介绍它. Mooij 等 [2016，定理 20] 利用 HSIC 的连续性，证明即使不进行样本分割，在无限数据极限下也能获得正确的 HSIC 值；但这里没有关于检验 p 值的任何主张. 最后一步值得特别关注，因为它涉及概率与因果性之间的关系. 根据拒绝和接受独立性的显著性水平，可能在两个方向、没有方向、或一个方向得到 ANM. 为强制作出决定，可以直接将拒绝独立性的 p 值较高的方向推断为因果方向.

近期研究提供了一些证据，表明这一过程在真实数据上的成功率高于随机水平 [Mooij 等, 2016]. 图 4.6 展示了真实数据[11]的散点图，其中只有因果方向的 ANM 拟合得相当好. 关于离散数据的修改，参见相关文献 [Peters 等, 2011a]. 注意，后非线性模型 (4.9) 在实践中比更标准的非线性回归模型 (4.3) 难拟合得多.

作为上述方法的替代，也可使用基于最大似然的方法. 例如，考虑一个具有加性高斯误差项的非线性 SCM. 此时可以比较两个模型的似然得分，区分 $X \to Y$ 和 $X \leftarrow Y$. 首先用 X 对 Y 进行非线性回归，得到残差 $R_Y := Y - \widehat{f}_Y(X)$. 然后比较

$$L_{X \to Y} = -\log \widehat{\mathrm{var}}[X] - \log \widehat{\mathrm{var}}[R_Y] \tag{4.18}$$

与交换 X, Y 的角色所得到的相应版本

$$L_{X \leftarrow Y} = -\log \widehat{\mathrm{var}}[R_X] - \log \widehat{\mathrm{var}}[Y]. \tag{4.19}$$

不难证明（见问题 4.16），如果不进行回归，而是使用真实条件均值 $\widehat{f}_Y(x) = \mathbb{E}[Y \mid X = x]$（$\widehat{f}_X$ 同理），这确实对应似然比较. 但如前所述，先回归再计算样本方差的两步过程需要论证. Bühlmann 等 [2014] 利用经验过程理论 [van de Geer, 2009] 证明相合性. 如果噪声不一定服从高斯分布，就必须调整得分函数，将残差经验方差的对数替换为误差项微分熵的估计 [Nowzohour 和 Bühlmann, 2016].

代码片段 4.14 以下代码给出有限数据集的一个例子. 它使用软件包 dHSIC [Pfister 等, 2017] 和 mgcv [Wood, 2006]. 前者包含函数 `dhsic.test`，实现了 Gretton 等 [2008] 提出的独立性检验；后者包含函数 `gam`，原代码第 10、11 行用它进行非线性回归（见第 A.1 节）. 只有反向的残差与输入之间独立性被拒绝，见原代码第 15、17 行. 原代码第 21、23 行表明高斯似然得分也偏向正向，另见式 (4.18) 和 (4.19).

```
library(dHSIC)
library(mgcv)
#
# generate data set
set.seed(1)
X <- rnorm(200)
Y <- X^3 + rnorm(200)
#
# fit models
```

[11] 这是因果对数据库中的 pair001：`https://webdav.tuebingen.mpg.de/cause-effect/`；另见 Mooij 等 [2016].

```
modelforw <- gam(Y ~ s(X))
modelbackw <- gam(X ~ s(Y))
#
# independence tests
dhsic.test(modelforw$residuals, X)$p.value
# [1] 0.7628932
dhsic.test(modelbackw$residuals, Y)$p.value
# [1] 0.004221031
#
# computing likelihoods
- log(var(X)) - log(var(modelforw$residuals))
# [1] 0.1420063
- log(var(modelbackw$residuals)) - log(var(Y))
# [1] -1.014013
```

4.2.2 信息几何因果推断

我们简要概述 IGCI 的实现，细节参见 Mooij 等 [2016]. 理论基础由定理 4.10 中的可识别性结果及其一些简单推论给出. 可以证明，独立性条件 (4.10) 蕴含

$$C_{X\to Y} \le C_{Y\to X},$$

如果定义

$$C_{X\to Y} := \int_0^1 \log f'(x) p(x)\,\mathrm{d}x,$$

而 $C_{Y\to X}$ 类似定义. 这里使用如下直接的估计量：

$$\widehat{C}_{X\to Y} := \frac{1}{N-1}\sum_{j=1}^{N-1} \log \frac{|y_{j+1}-y_j|}{|x_{j+1}-x_j|},$$

其中 $x_1 < x_2 < \cdots < x_N$ 是按升序排列的观测 x 值. 如果 Y 是 X 的递增函数，y 值也有序；但对真实数据通常并非如此. $\widehat{C}_{Y\to X}$ 相应定义，只要 $\widehat{C}_{X\to Y} < \widehat{C}_{Y\to X}$，就推断 $X \to Y$. 除了所谓的基于斜率的方法，还有基于熵的方法. 可以证明式 (4.10) 还蕴含

$$H(X) \le H(Y),$$

其中 H 是微分 Shannon 熵：

$$H(X) := -\int_0^1 p(x)\log p(x)\,\mathrm{d}x.$$

直观地说，原因是将非线性函数 f 应用于 p_X 会产生额外的不规则性（除非 f 的非线性相对于 p_X 经过调节），因此使 p_Y 比 p_X 更不均匀. 相应地，假定熵较大的变量是原因. 为估计 H，可以使用文献中的任何标准熵估计量.

译注：源文保留 $H(X) \le H(Y)$，后文却称熵较大的变量为原因，与此处 X 为原因的方向有表面冲突. 不把该表述当作已确认的普适方向判据.

4.2.3 迹方法

回忆一下，该方法依赖高维变量 $\mathbf{X}, \mathbf{Y}$ 之间的线性关系. 首先假设样本量（与 $\mathbf{X}, \mathbf{Y}$ 的维数相比）足够大，能够通过标准线性回归估计协方差矩阵 Σ_{XX}, Σ_{YY} 和结构矩阵 A_Y, A_X. 为利用定理 4.12 的可识别性结果，可以计算迹依赖比

$$r_{X\to Y} := \frac{\tau(A_Y \Sigma_{XX} A_Y^T)}{\tau(A_Y A_Y^T)\tau(\Sigma_{XX})},$$

并通过交换 $\mathbf{X}, \mathbf{Y}$ 的角色类似地计算 $r_{Y\to X}$，推断更接近 1 的方向对应因果方向 [Janzing 等, 2010] .

Zscheischler 等 [2011] 描述了一种评估偏离 1 是否显著的方法：在其生成模型中，通过某个随机正交映射使矩阵 A 与 Σ_{XX} 相对旋转，模拟二者独立性. 利用自由概率论 [Voiculescu, 1997]——描述大型随机矩阵渐近行为的数学框架——的思想，Zscheischler 等 [2011] 为维数大于样本量的情形构造了迹条件的实现. 他们证明，在无噪声情形下，即使数据不足以估计 Σ_{XX} 和 A，在 A 与 $\mathbf{X}$ 的经验协方差矩阵之间附加独立性假设后，仍可估计 $r_{X\to Y}$. 因此，只要估计量显著偏离 1，就可以拒绝假设 $X \to Y$. 此时，要么附加独立性假设错误，要么 $r_{X\to Y}$ 显著偏离 1.

4.2.4 监督学习方法

最后介绍一种从更偏机器学习的观点处理因果学习的方法. 原则上，它既可以利用受限函数类，也可以利用独立性条件. 假设给定形式为 $(D_1, A_1), \ldots, (D_n, A_n)$ 的带标签训练数据. 此处每个 D_i 是数据集

$$D_i = \{(X^1, Y^1), \ldots, (X^{n_i}, Y^{n_i})\},$$

包含从 $(X^1, Y^1), \ldots, (X^{n_i}, Y^{n_i}) \overset{\text{iid}}{\sim} P^i_{X,Y}$ 得到的实现值；每个标签 $A_i \in \{\to, \leftarrow\}$ 描述数据集 D_i 对应 $X \to Y$ 还是 $X \leftarrow Y$. 因果学习于是成为经典预测问题，可以训练分类器，希望其从真实方向已知的数据集良好地泛化到未见过的测试数据集.

据我们所知，Guyon [2013] 最先以挑战赛的形式系统研究此类方法（提供混合的合成与真实数据集作为真实方向已知的数据）. 显然，方法不能通过利用相关或协方差等对称特征而成功.

挑战赛中许多有竞争力的分类器基于人工设计的特征，例如边缘分布的熵估计，或用 Y 回归 X、用 X 回归 Y 后所得残差分布的熵估计. 有趣的是，这些特征可以与 ANM 的概念联系起来. 例如，对于高斯分布变量，熵是方差对数的线性函数，因此这些特征足以重构得分 (4.18) 和 (4.19). 考虑熵而不是方差对数，相当于放松高斯性假设 [Nowzohour 和 Bühlmann, 2016] .

Lopez-Paz 等 [2015] 旨在自动构造这类特征. 思路是将联合分布 $P^i_{X,Y}$ $(i = 1, \ldots, n)$ 映射到一个再生核 Hilbert 空间（见附录 A.2），并在该空间中进行分类. 实际上无法获得完整分布 $P^i_{X,Y}$，而是用经验分布近似.（类似方法已被用来区分时间反演后的时间序列与其原始版本 [Peters 等, 2009a] .）由于区分原因与结果似乎依赖联合分布的相对复杂性质，需要较大的训练集样本量 n. 为添加有用的模拟数据集，必须从可识别情形生成这些数据. 例如，Lopez-Paz 等 [2015] 使用了来自 ANM 的额外样本.

监督学习方法目前还不能作为独立的因果学习方法. 不过，它们可能作为统计工具发挥作用，高效利用已知的可识别性性质或其组合.

4.3 习题

问题 4.15（ANM）

a) 考虑 SCM

$$\begin{aligned} X &:= N_X, \\ Y &:= 2X + N_Y, \end{aligned}$$

其中 N_X 在 1 和 3 之间均匀分布，N_Y 在 -0.5 和 0.5 之间均匀分布且独立于 N_X. 分布 $P_{X,Y}$ 容许从 X 到 Y 的 ANM. 画出 X, Y 联合分布的支撑，并自行确认 $P_{X,Y}$ 不容许从 Y 到 X 的 ANM，即不存在函数 g 和相互独立的噪声变量 M_X, M_Y，使得

$$\begin{aligned} X &= g(Y) + M_X, \\ Y &= M_Y, \end{aligned}$$

其中 M_X 与 M_Y 独立.

b) 类似于 a)，考虑 SCM

$$\begin{aligned} X &:= N_X, \\ Y &:= X^2 + N_Y, \end{aligned}$$

其中 N_X 在 1 和 3 之间均匀分布，N_Y 在 -0.5 和 0.5 之间均匀分布且独立于 N_X. 再次画出 $P_{X,Y}$ 的支撑，并自行确认不存在从 Y 到 X 的 ANM.

问题 4.16（最大似然） 假设给定来自以下模型的独立同分布数据集

$$(X^1, Y^1), \ldots, (X^n, Y^n).$$

$$\begin{aligned} &Y = f(X) + N_Y, \\ &X \sim \mathcal{N}(\mu_X, \sigma_X^2), \quad N_Y \sim \mathcal{N}(\mu_{N_Y}, \sigma_{N_Y}^2) \text{ 且相互独立}, \end{aligned}$$

其中函数 f 假定已知.

a) 证明 $f(x) = \mathbb{E}[Y \mid X = x]$.

b) 记 $\mathbf{x} := (x_1, \ldots, x_n)$、$\mathbf{y} := (y_1, \ldots, y_n)$，考虑对数似然函数

$$\ell_\theta(\mathbf{x}, \mathbf{y}) = \ell_\theta((x_1, y_1), \ldots, (x_n, y_n)) = \sum_{i=1}^{n} \log p_\theta(x_i, y_i),$$

其中 p_θ 是 (X, Y) 的联合密度，$\theta := (\mu_X, \mu_{N_Y}, \sigma_X^2, \sigma_{N_Y}^2)$. 证明存在 $c_1, c_2 \in \mathbb{R}$ 且 $c_2 > 0$，使得

$$\max_\theta \ell_\theta(\mathbf{x}, \mathbf{y}) = c_2 \cdot (c_1 - \log \widehat{\mathrm{var}}[\mathbf{x}] - \log \widehat{\mathrm{var}}[\mathbf{y} - f(\mathbf{x})]) \,, \tag{4.20}$$

其中 $\widehat{\mathrm{var}}[\mathbf{z}] := \frac{1}{n} \sum_{i=1}^n (z_i - \frac{1}{n} \sum_{k=1}^n z_k)^2$ 估计方差.

式 (4.20) 为比较式 (4.18) 和 (4.19) 提供动机. 主要区别在于，本习题使用条件均值而不是回归方法的结果. 可以证明后者在渐近情况下仍会产生正确结果 [Bühlmann 等, 2014] .

译注：本题允许噪声均值 μ_{N_Y} 任意，却要求证明 $f(x) = E[Y \mid X = x]$. 一般应有 $E[Y \mid X = x] = f(x) + \mu_{N_Y}$，原结论还需零均值条件. 题目照源保留.

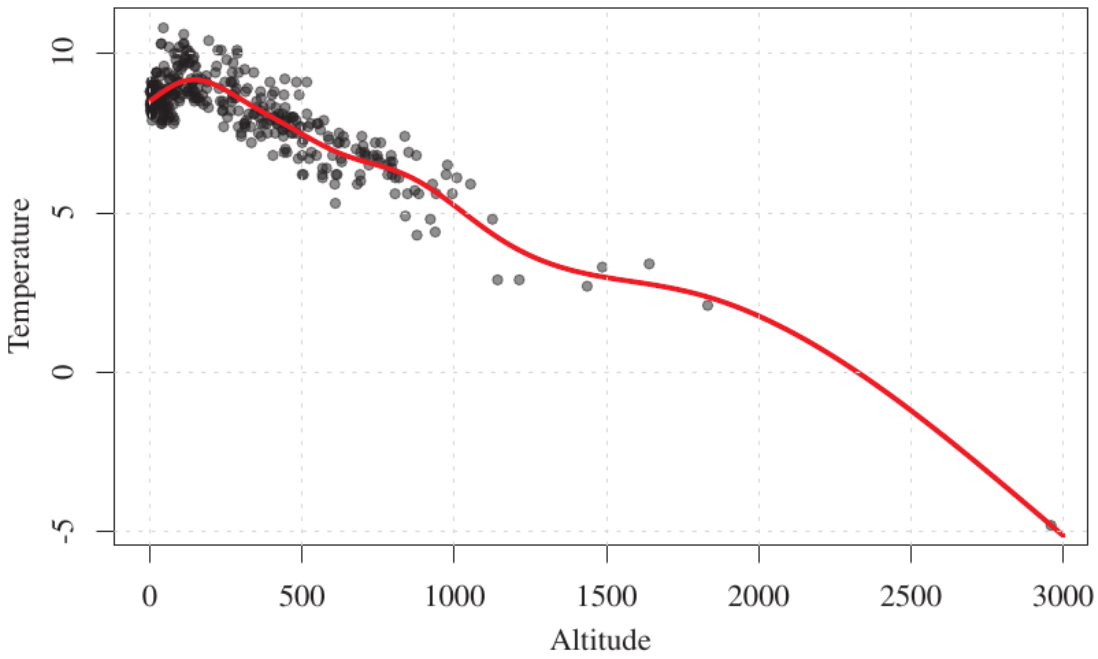


图 4.6: 德国各地平均温度（Y，摄氏度）与海拔（X，米）之间的关系. 数据来自 Deutscher Wetterdienst；另见 Mooij 等 [2016]. 带加性噪声的非线性函数（在远离海平面的区域接近线性）能够相当好地拟合这些经验观测. 原图 temperature 为温度，altitude 为海拔.

Chapter 5

与机器学习的联系，I

正如第 1 章所论证，标准机器学习与统计学建立在同一基础上：利用从某个未知底层分布独立同分布采样得到的数据，试图推断该分布的性质. 相比之下，因果推断假设更强的底层结构，包括有向依赖关系. 这使从数据学习结构更加困难，但一旦完成，也可以作出新的陈述，包括关于分布偏移与干预效果的陈述. 如果我们把机器学习看作推断超越纯统计关联的规律（或“自然规律”）的过程，那么因果性便发挥关键作用. 本章就此提出一些想法，只关注两个变量的情形；第 8 章将回到这一主题并考察多变量情形.

5.1 半监督学习

考虑一个回归任务，目标是根据 d 维预测变量 $\mathbf{X}$ 预测目标变量 Y. 对许多损失函数，知道条件分布 $P_{Y|\mathbf{X}}$ 就足以解决问题. 例如，回归函数

$$f^0(x) := \mathbb{E}[Y \mid \mathbf{X} = x]$$

最小化 L_2 损失：

$$f^0 \in \operatorname*{argmin}_{f:\mathbb{R}^d \to \mathbb{R}} \mathbb{E}[(Y - f(\mathbf{X}))^2].$$

在监督学习中，我们从联合分布接收 n 个独立同分布数据点

$$(\mathbf{X}^1, Y^1), \ldots, (\mathbf{X}^n, Y^n) \overset{\text{iid}}{\sim} P_{\mathbf{X},Y}.$$

因此，(具有 L_2 损失的)回归估计相当于根据联合分布的 n 个数据点估计条件均值. 但在(归纳式) 半监督学习 (SSL) 中，我们还接收 m 个无标签数据点 $\mathbf{X}^{n+1}, \ldots, \mathbf{X}^{n+m} \overset{\text{iid}}{\sim} P_{\mathbf{X}}$. 希望这些额外数据点能提供关于 $P_{\mathbf{X}}$ 的信息，而后者又能告诉我们一些关于 $\mathbb{E}[Y \mid \mathbf{X}]$ 或更一般的 $P_{Y|\mathbf{X}}$ 的信息.[1] 许多 SSL 技术的基础假设 [综述见 Chapelle 等, 2006] 涉及 $P_{\mathbf{X}}$ 与 $P_{Y|\mathbf{X}}$ 之间的关系. 例如，聚类假设规定处在 $P_{\mathbf{X}}$ 同一簇中的点具有相同或相近的 Y；这类似于低密度分离假设：分类器的决策边界 (即 $P(Y = 1 \mid \mathbf{X} = x)$ 穿过 0.5 的点 x) 应位于 $P_{\mathbf{X}}$ 较小的区域. 半监督光滑性假设指出，条件均值 $x \mapsto \mathbb{E}[Y \mid \mathbf{X} = x]$ 在 $P_{\mathbf{X}}$ 较大的区域应当光滑.

5.1.1 SSL 与因果方向

在最简单的因果图只有两个变量 (原因与结果) 的情形中，机器学习问题可以是因果的 (由原因预测结果)，也可以是反因果的 (由结果预测原因) . 实践者通常不关心给

[1] 这里再次用记号 $P_{Y|\mathbf{X}}$ 简写条件分布的集合 $(P_{Y|\mathbf{X}=x})_x$.

定学习问题背后的因果结构（见图 5.1）. 不过，如我们在这里所论证的，这一结构对机器学习有影响.

在第 2.1 节中，我们假设因果条件分布相互独立（原则 2.1 及后续讨论）. Schölkopf 等 [2012] 认识到，这一原则对 SSL 有直接影响. 由于 SSL 依赖 P_X 与 $P_{Y|X}$ 之间的关系，而该原则声称 P_{cause} 与 $P_{\text{effect}|\text{cause}}$ 彼此不含信息，我们可以得出：如果 X 对应原因、Y 对应结果（即因果学习问题），SSL 将不起作用. 此时，额外的 x 值只会让我们更了解 P_X，这并不相关，因为预测需要关于独立对象 $P_{Y|X}$ 的信息. 另一方面，如果 X 是结果、Y 是原因，关于 P_X 的信息可能告诉我们一些关于 $P_{Y|X}$ 的信息.

一项分析 SSL 结果的元研究支持我们的假设：SSL 有帮助的所有情形都是反因果、有混杂，或因果结构不明确的例子（见图 5.2）.

在双射确定性因果关系的玩具情景中（见第 4.1.7 节），Janzing 和 Schölkopf [2015] 证明：只要 P_{cause} 与 $P_{\text{effect}|\text{cause}}$ 在式 (4.10) 的意义下独立，那么 SSL 在反因果方向确实优于监督学习，但在因果方向不然. 其思想是 SSL 利用依赖关系 (4.11) 改进插值算法.

Sgouritsa 等 [2015] 开发了一种因果学习方法，利用了 SSL 只能在反因果方向起作用这一事实. 最后注意，SSL 将某些无监督学习形式作为特例包含在内（无标签数据的情形）. 例如在聚类中，Y 常是表示聚类编号的离散值. 类似前面的推理，我们可以论证：如果 X 是原因、Y 是结果，聚类应当表现不佳. 不过，在许多真实数据聚类应用中，聚类编号更像是特征的原因，而非结果.

尽管图 5.2 的经验结果令人鼓舞，“SSL 在因果方向不起作用” 这一陈述（始终假设原因与机制独立，参见原则 2.1）仍需更精确地表述. 下一节将完成这一点；对 SSL 和协变量偏移感兴趣的读者可能会觉得有用，其他读者初读时可跳过.

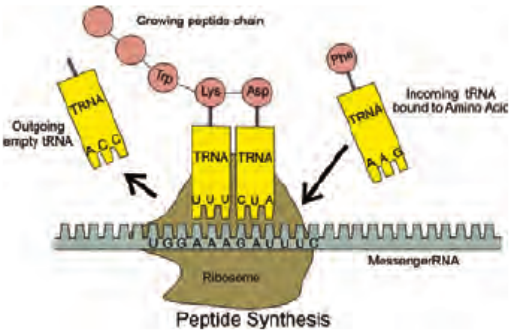
5.1.2 关于因果方向 SSL 的一个注记

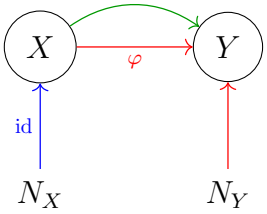
我们关于 SSL 的预测可以更精确地表述为：如果任务是针对某个特定 x 预测 y，那么当 $X \to Y$ 是因果方向时，知道 P_X 没有帮助. 但是，即使 P_X 并不告诉我们任何关于 $P_{Y|X}$ 的信息（由于 $X \to Y$），知道 P_X 仍然有助于更好地估计 Y，因为我们可以在学习情景中获得更低的风险.

为说明这一点，考虑一个玩具例子：X, Y 之间的关系由确定性函数给出，即 $Y = f(X)$，已知 f 属于某个函数类 $\mathcal{F}$. 令 X 在 $\{1, \dots, m\}$ 中取值，$m \geq 3$；令 Y 为取值于 $\{0, 1\}$ 的二元标签. 我们通过 $f_j(j) = 1$ 和 $f_j(k) = 0$ $(k \neq j)$ 定义函数类 $\mathcal{F} := \{f_1, \dots, f_m\}$. 换言之，$\mathcal{F}$ 由恰好在一个点取值 1 的函数构成. 图 5.3 上图显示 $m = 4$ 时的函数 f_3. 假设学习算法推断出 f_j，而真实函数为 f_i. 对于 $i \neq j$，风险，即错误的期望数量（见式 (1.2)），等于

$$R_i(f_j) := \sum_{x=1}^{m} |f_j(x) - f_i(x)| p(x) = p(j) + p(i), \tag{5.1}$$

其中 p 是 X 的概率质量函数. 现在对集合 $\mathcal{F}$ 中的 $R_i(f_j)$ 取平均，并假设每个 f_i 等可







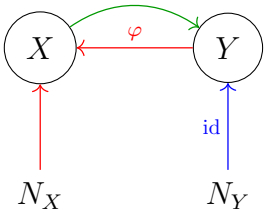


图 5.1: 上：称为核糖体的复杂机制 φ 将 mRNA 信息 X 翻译成蛋白质链 Y. 从 mRNA 预测蛋白质是因果学习问题的例子：预测方向（绿箭头）与因果方向（红箭头）一致. 下：手写数字识别中，我们试图从书写者产生的图像 X 推断类别标签 Y（即书写者的意图），这是反因果问题. 上图的核糖体图像由用户 Boumphreyfr 提供，https://commons.wikimedia.org/wiki/File:Peptide_syn.png，原书注明 CC BY-SA 3.0（http://creativecommons.org/licenses/by-sa/3.0）或 GFDL（http://www.gnu.org/copyleft/fdl.html）. 图中英文 Peptide Synthesis 为肽合成，ribosome 为核糖体，Messenger RNA 为信使 RNA，growing peptide chain 为增长中的肽链.

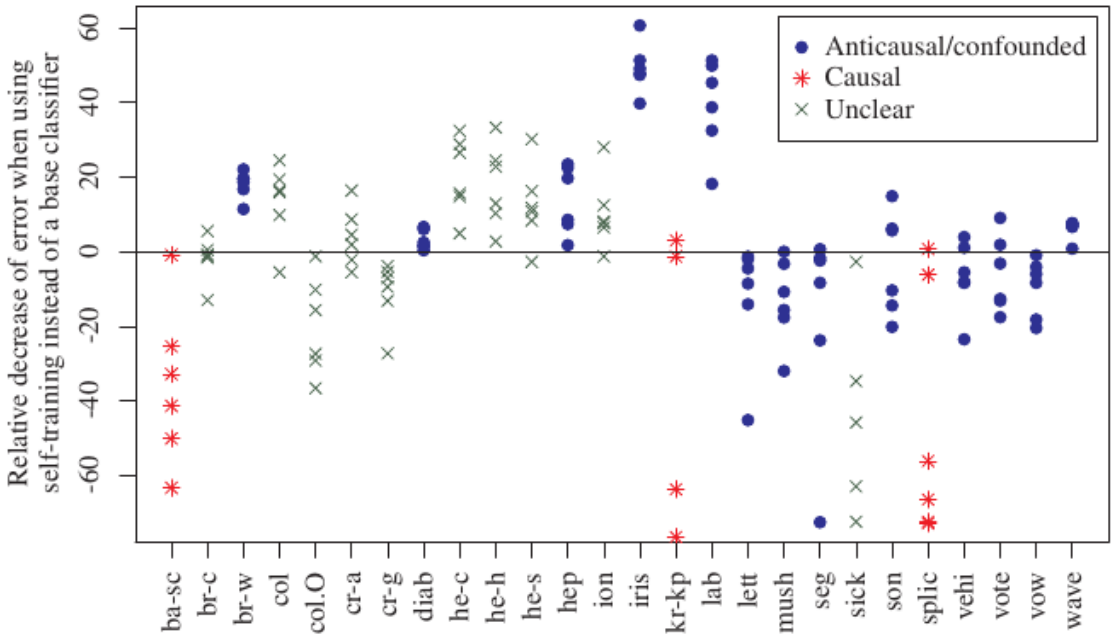


图 5.2: SSL 的收益取决于因果结构. 每一列点对应 UCI 仓库中的一个基准数据集，显示六种不同基础分类器加上自训练（一种通用 SSL 方法）后的性能. 性能以相对于基础分类器的误差百分比下降衡量，即 (error(base) − error(self-train))/ error(base). 总体上，自训练对因果数据集无帮助，但对部分反因果 / 混杂数据集有帮助［据 Schölkopf 等, 2012］. 原图图例 anticausal/confounded、causal、unclear 分别为反因果 / 有混杂、因果、未确定.

能. 这样得到期望风险（期望相对于 $\mathcal{F}$ 上的均匀先验）：

$$\mathbb{E}[R_i(f_j)] = \frac{1}{m}\sum_{i=1}^{m}\sum_{x=1}^{m}|f_j(x) - f_i(x)|p(x) \tag{5.2}$$

$$= \frac{1}{m}\sum_{i\neq j}(p(j) + p(i)) = \frac{m-2}{m}p(j) + \frac{1}{m}. \tag{5.3}$$

因此，为使式 (5.3) 最小，我们应选择使函数 p 达到最小的 k 所对应的 f_k. 这很有道理，因为对任意点 $x = 1, \ldots, m$，标签 $y = 0$ 都比 $y = 1$ 更可能（概率分别为 $(m-1)/m$ 与 $1/m$）. 因此，我们实际上希望处处推断为 0，但由于零函数不属于 $\mathcal{F}$，被迫选择一个 x 值并给它赋标签 0. 因而，为获得最小期望损失，我们选择概率最小的 x 值之一（对于图 5.3 下图中的分布，这个值是 $x = 3$）. 显然，无标签观测有助于识别概率最小的 x 值，因此 SSL 可以有帮助.

译注：源句印为在一个位置赋标签 *0*；但本例函数类要求恰有一个位置标签为 *1*，图注及风险推导也对应标签 *1*. 此处保留源句并指出冲突.

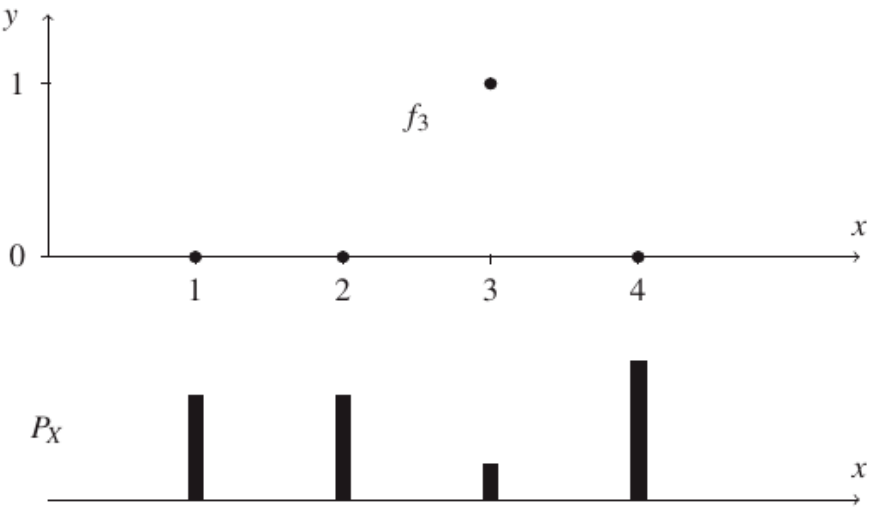


图 5.3: 本例中，即使在因果方向，SSL 也能降低损失. 因为对每个 x，标签 0 先验地比标签 1 更可能，选择在 $p(x)$ 最小的点（这里为 $x = 3$）取值为 1 的函数时，期望错误数达到最小.

该例不需要任何 (x, y) 对（带标签实例）；无标签数据 x 已经足够. 因此，严格说来它是无监督学习的例子，而不是典型的 SSL 情景. 不过，额外考虑少量带标签实例并不改变基本思想. 一般来说，如果 m 足够大，这些少数实例中不会有任何 $y = 1$ 的实例. 因而观测到的 (x, y) 对的帮助仅在于把 $\mathcal{F}$ 稍微缩小为一个更小的类别 $\mathcal{F}'$；分析基本相同，仍然得到无标签实例有帮助的结论.

尽管我们尚未指定监督学习情景作为基线（即不利用 P_X 的知识），我们知道它一定比最佳半监督情景更差，因为如上所述，最优估计依赖于 P_X.

这里没有违反机制独立性（因而 X 可被视为 Y 的原因）：假设 f 从 $\mathcal{F}$ 中均匀选取，知道 P_X 不会告诉我们任何关于 f 的信息. 知道 P_X 之所以对最小化损失有帮助，仅仅是因为 $p(x)$ 在式 (5.2) 中作为加权因子出现.

前面的例子在精神上接近贝叶斯分析，因为它涉及对 $\mathcal{F}$ 中函数取平均. 但可以修改它，使其适用于最坏情况分析：由对手选择真实函数 f 以最大化式 (5.1) [另见 Kääriäinen, 2005]. 给定函数 f_j，对手选择满足 $i \neq j$ 且具有最大概率质量的 x 值 i 所对应的 f_i. 因此最坏情况风险为 $\max_{x \neq j}\{p(x)\} + p(j)$，而选择使概率质量函数 $p(x)$ 最小的 x 值作为 j，再次使这一风险最小. 因而我们得出，只有考虑 P_X 才能达到最优性能.

另一个例子可以基于 Urner 等 [2011，定理 4 的证明] 在非因果背景下给出的论证构造. 他们构造了一个模型设定错误的情形：真实函数 f_0 不在所优化的类别 $\mathcal{F}$ 内. 在他们的例子中，尽管条件分布 $P_{Y|X}$ 可以被视为独立于边缘分布，关于边缘分布 P_X 的额外信息仍有助于降低风险. 我们前面的例子并不基于同一种模型设定错误：每个可能的（未知）真实函数 f_i 都属于函数类；但是，我们希望最小化风险对先验的期望，而该函数类不包含一个期望风险为零的函数. 因此，对期望风险而言，这类似于模型设定错误的情形.

最后，进一步给出关于 Urner 等 [2011] 例子的直觉. 由于 f_0 不在函数类 $\mathcal{F}$ 中，我们需要在 $f \in \mathcal{F}$ 中找到一个函数 $\widehat{f}$，使距离 $d(f, f_0)$ 最小，其中距离定义为 f 的风险；我们称 f_0 被投影到 $\mathcal{F}$ 上. 粗略地说，关于 P_X 的额外信息使我们更好地理解这一投影.[2]

5.2 协变量偏移

如第 2.1 节所解释，P_{cause} 与 $P_{\text{effect}|\text{cause}}$ 的独立性（原则 2.1）可以有两种解释：在前面的第 5.1 节中，我们认为给定固定的联合分布，这两个对象彼此不含信息（见图 2.2 中间的框）. 另一种解释是假设联合分布 $P_{\text{cause,effect}}$ 在不同数据集之间变化；此时 P_{cause} 的变化不会告诉我们任何关于 $P_{\text{effect}|\text{cause}}$ 变化的信息（对应图 2.2 左框）.

因此，在从 X 预测 Y 的情景中，知道 X 是原因、Y 是结果具有重要后果. 假设我们已用某个数据集的例子学到 X, Y 之间的统计关系，需要利用该知识在第二个数据集中从 X 预测 Y. 再假设我们观测到第二个数据集中的 x 值服从与第一个数据集的 P_X 不同的分布 P'_X. 应如何利用这一信息？根据机制独立性，P'_X 与 P_X 不同这一事实，并不告诉我们 $P_{Y|X}$ 在两个数据集之间是否也发生了变化. 因此，条件分布 $P_{Y|X}$ 可能对第二个数据集仍然成立. 其次，即使条件分布确实变化为 $P'_{Y|X} \neq P_{Y|X}$，仍然用 $P_{Y|X}$ 预测也是自然的：毕竟独立性原则指出，边缘分布从 P_X 变为 P'_X 并不告诉我们条件分布如何变化. 因此，在没有更好候选者时，我们使用 $P_{Y|X}$. 尽管 P_X 已变，仍使用同一个条件分布 $P_{Y|X}$，通常称为协变量偏移. 如今这是机器学习中得到充分研究的假设 [Sugiyama 和 Kawanabe, 2012]. Schölkopf 等 [2012] 论证过，这只在因果情景中，即 X 是原因、Y 是结果时才有理由.

为了进一步说明，考虑下面 X 是结果的反因果玩具情景. 设 Y 为二元变量，以加性方式影响实值变量 X：

$$X = Y + N_X, \tag{5.4}$$

其中假设 N_X 是独立于 Y 的高斯噪声. 图 5.4 左图展示对应的概率密度 p_X.

[2]我们感谢为这一讨论作出贡献的几位人士：Sebastian Nowozin、Ilya Tolstikhin 和 Ruth Urner.

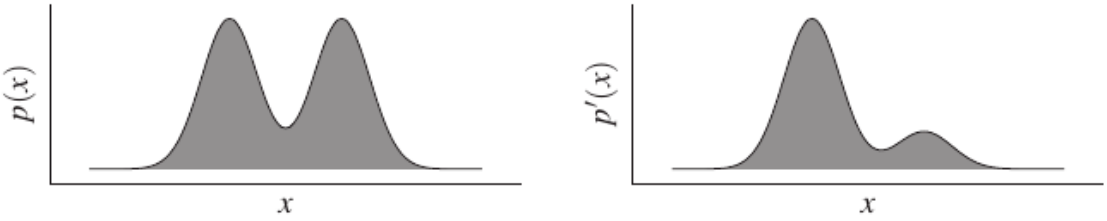


图 5.4: P_X 变为 P'_X 的一个例子；这种变化暗示 P_Y 已变，而 $P_{X|Y}$ 保持不变. 当 Y 是已知为 X 之原因的二元变量时，观测到 P_X 是两个高斯分布的混合，使人有理由认为两个模态对应不同标签 $y = 0, 1$. 此时 Y 对 X 的影响只表现为平移高斯分布的均值（这构成 ANM，见第 4.1.4 节），这无疑是对联合分布的简单解释. 如果进一步观测到混合权重从一个数据集到另一个数据集发生变化，就很可能是 P_Y 发生了变化.

如果其宽度足够小，分布 P_X 具有双峰. 即使对生成模型一无所知，也可以认出 P_X 是两个等宽高斯分布的混合. 因此在这种情况下，仅凭 P_X 就可以猜测联合分布 $P_{X,Y}$，因为自然的假设是 Y 的影响只在于平移 X 的均值. 在这一假设下，不需要任何 (x, y) 对就能学习 X, Y 的关系. 现在假设，在第二个数据集中观测到同样的两个高斯分布的混合，但权重不同（见图 5.4 右图）. 那么最自然的结论是：权重变化是因为同一个方程 (5.4) 仍成立，只是 P_Y 发生了变化. 相应地，我们不再使用相同的 $P_{Y|X}$ 来预测，而是从 P'_X 重构 $P'_{Y|X}$. 这个例子表明，在反因果情景中，P_X 与 $P_{Y|X}$ 的变化可能相关，而这种关系可能源于 P_Y 已变而 $P_{X|Y}$ 保持不变. 换言之，由于 P_{cause} 与 $P_{\text{effect|cause}}$ 独立变化，P_{effect} 与 $P_{\text{cause|effect}}$ 往往以相依方式变化.

前一个例子提出的是特定情景. 构想利用 P_{effect} 与 $P_{\text{cause|effect}}$ 以相依方式变化这一事实的一般方法，是一个困难的问题. 这可能是有趣的后续研究方向，我们认为因果性可能在领域适应和迁移问题中发挥重要作用；另见 Bareinboim 和 Pearl [2016]、Rojas-Carulla 等 [2016]、Zhang 等 [2013] 和 Zhang 等 [2015].

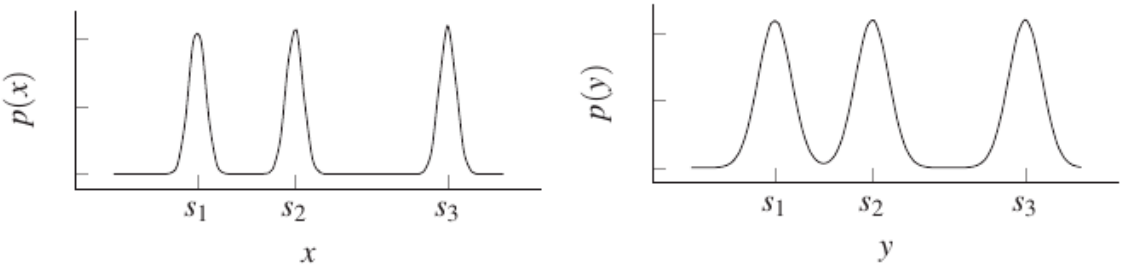


图 5.5: 一个 X 导致 Y，因而 P_Y 和 $P_{X|Y}$ 彼此包含信息的例子. 左：P_X 是位置 s_1, s_2, s_3 处尖峰的混合. 右：P_Y 由 P_X 与零均值高斯噪声卷积得到，因此由相同位置 s_1, s_2, s_3 处较不尖锐的峰构成. 此时 $P_{X|Y}$ 也包含关于 s_1, s_2, s_3 的信息（见问题 5.1）.

5.3 习题

问题 5.1（机制独立性） 设 P_X 是位置 $s_1, \ldots, s_k$ 处 k 个尖锐高斯峰的混合，如图 5.5 左图所示. 设 Y 由 X 加上某个均值为零、宽度为 σ_N 的高斯噪声 N 得到，使各个峰仍如图 5.5 右图所示可见.

a) 直观论证为什么 $P_{X|Y}$ 也包含关于峰位置 $s_1, \ldots, s_k$ 的信息，因而 $P_{X|Y}$ 与 P_Y 共享这些信息.

b) P_X 与 P_Y 之间的转换可由卷积（从 P_X 到 P_Y）与反卷积（从 P_Y 到 P_X）描述. 如果将 $P_{Y|X}$ 视为把输入 P_X 转换为输出 P_Y 的线性映射，那么 $P_{Y|X}$ 与卷积映射一致. 试说明为什么 $P_{X|Y}$ 不与反卷积映射一致（尽管乍看似乎如此）.

Chapter 6

多变量因果模型

第 3 章讨论了两个变量的因果模型. 虽然一些基本概念在双变量情形更容易解释, 因果推断的许多结构却来自涉及至少三个变量的多变量关系. 现在考虑 $d \geq 2$ 个变量的更一般的因果模型.

许多概念可以直接推广; 我们希望读者借助第 3 章获得的直觉, 能够容易地理解 SCM (第 6.2 节)、干预 (第 6.3 节) 和反事实 (第 6.4 节) 的定义. 但与双变量情形也存在根本区别. 在第 6.5 节, 我们将看到图结构蕴含一些在双变量情形下平凡的条件独立性陈述. 此外, 在多变量情形下计算干预分布需要更多思考: 我们将在第 6.6 节讨论调整公式和 *do* 演算 [Pearl, 2009] .

首先介绍一些图论术语. 大多数定义不言自明, 例如可见 Spirtes 等 [2000]、Koller 和 Friedman [2009] 及 Lauritzen [1996]. 已熟悉图模型的读者或许希望跳过本节. 对本书最重要的术语是有向无环图 (DAG)、v 结构和 d 分离.

6.1 图论术语

考虑有限多个随机变量 $\mathbf{X} = (X_1, \ldots, X_d)$, 其指标集为 $V := \{1, \ldots, d\}$, 联合分布为 $P_{\mathbf{X}}$, 密度为 $p(x)$. 图 $\mathcal{G} = (V, E)$ 由 (有限多个) 节点或顶点 V 和边 $E \subseteq V^2$ 组成, 且对任意 $v \in V$, $(v, v) \notin E$. 进一步有以下定义.

设 $\mathcal{G} = (V, E)$ 是一个图, 其中 $V := \{1, \ldots, d\}$, 对应随机变量 $\mathbf{X} = (X_1, \ldots, X_d)$. 如果 $V_1 = V$ 且 $E_1 \subseteq E$, 则称图 $\mathcal{G}_1 = (V_1, E_1)$ 是 $\mathcal{G}$ 的子图, 记作 $\mathcal{G}_1 \leq \mathcal{G}$. 如果还满足 $E_1 \neq E$, 则 $\mathcal{G}_1$ 是 $\mathcal{G}$ 的真子图.

如果 $(i, j) \in E$ 且 $(j, i) \notin E$, 则节点 i 称为 j 的父节点; 如果 $(j, i) \in E$ 且 $(i, j) \notin E$, 则称 i 是 j 的子节点. j 的父节点集合记为 $\mathbf{PA}_j^{\mathcal{G}}$, 子节点集合记为 $\mathbf{CH}_j^{\mathcal{G}}$. 如果 $(i, j) \in E$ 或 $(j, i) \in E$, 则两个节点 i, j 相邻. 如果所有节点对都相邻, 称 $\mathcal{G}$ 是全连接的. 对相邻节点 i, j, 若 $(i, j) \in E$ 且 $(j, i) \in E$, 则称它们之间有一条无向边. 两个相邻节点之间的边若不是无向边, 则是有向边; 此时若 $(i, j) \in E$, 记为 $i \to j$. 如果所有边都有向, 称 $\mathcal{G}$ 是有向图.[1] 如果三个节点中的一个是另外两个彼此不相邻节点的共同子节点, 称它们构成非道德结构 (immorality) 或 v 结构. $\mathcal{G}$ 的骨架不考虑边的方向; 它是图 $(V, \widetilde{E})$, 其中当 $(i, j) \in E$ 或 $(j, i) \in E$ 时有 $(i, j) \in \widetilde{E}$.

$\mathcal{G}$ 中的路径是一个由 (至少两个) 互不相同的顶点组成的序列 $i_1, \ldots, i_m$, 使得对所有 $k = 1, \ldots, m-1$, i_k 和 i_{k+1} 之间有边. 如果 $i_{k-1} \to i_k$ 且 $i_{k+1} \to i_k$, 则称 i_k 是相对于该路径的碰撞点. 如果对所有 k 都有 $i_k \to i_{k+1}$, 则称这是一条从 i_1 到 i_m 的有向路径, 并称 i_1 是 i_m 的祖先、i_m 是 i_1 的后代. 本书将 i 的所有祖先记为 $\mathbf{AN}_i^{\mathcal{G}}$, 且 i 不是自身的祖先. 此外, i 既不是自身的后代, 也不是自身的非后代. 我们将 i 的所有后代记

[1] 注意, 这排除了长度为 2 的环, 但不排除更长的环.

为 $\mathbf{DE}_i^{\mathcal{G}}$，将不包括 i 自身的所有非后代记为 $\mathbf{ND}_i^{\mathcal{G}}$. 本书的 $\mathbf{ND}_i^{\mathcal{G}}$ 包含图 $\mathcal{G}$ 中 i 的父节点. 没有父节点的节点称为源节点，没有子节点的节点称为汇节点. 如果排列，即双射 $\pi : \{1, \dots, d\} \to \{1, \dots, d\}$ 满足：当 $j \in \mathbf{DE}_i^{\mathcal{G}}$ 时 $\pi(i) < \pi(j)$，则称其为拓扑序或因果序（另见附录 B）.

如果图 $\mathcal{G}$ 没有有向环，即不存在一对 (j, k)，使得既有从 j 到 k 的有向路径，也有从 k 到 j 的有向路径，则称其为部分有向无环图（PDAG）. 如果 $\mathcal{G}$ 是 PDAG 且所有边都有向，则称其为有向无环图（DAG）.

由于下文多处将使用 d 分离这一图论概念 [Pearl, 1985; Pearl, 1988]，我们将其表述为定义.

定义 6.1（Pearl 的 d 分离） d 分离（d-separation）定义如下. 在 DAG $\mathcal{G}$ 中，如果节点 i_1 与 i_m 之间的路径存在节点 i_k，使得以下两种情况之一成立，则称该路径被集合 S 阻断（i_1, i_m 均不在 S 中）：

(i) $i_k \in S$ 且

$$i_{k-1} \to i_k \to i_{k+1} \quad \text{或} \quad i_{k-1} \leftarrow i_k \leftarrow i_{k+1} \quad \text{或} \quad i_{k-1} \leftarrow i_k \to i_{k+1};$$

(ii) i_k 和它的所有后代均不在 S 中，且

$$i_{k-1} \to i_k \leftarrow i_{k+1}.$$

此外，在 DAG $\mathcal{G}$ 中，如果顶点的两个不相交子集 A, B 之间的每条路径都被第三个（同样与二者不相交的）子集 S 阻断，则称 A 与 B 被 S d 分离，记作

$$A \perp\!\!\!\perp_{\mathcal{G}} B \mid S.$$

读者可以观察图 6.5，确认对于该 DAG，有 $C \perp\!\!\!\perp_{\mathcal{G}} G \mid X$，但 $C \not\perp\!\!\!\perp_{\mathcal{G}} G \mid (X, H)$.

6.2 结构因果模型

SCM 在农业、社会科学和计量经济学等领域已有长期使用历史 [Wright, 1921; Haavelmo, 1944; Bollen, 1989]，另见第 2 章. 例如，模型选择曾通过拟合若干根据系统先验知识被视为合理的不同结构来完成，然后用拟合优度检验比较这些候选结构. 本章介绍 SCM 的语义，并学习如何使用它们计算干预分布等. 在整章中，我们将假设 SCM 或至少其结构已给定. 第 7 章讨论识别结构的问题.

定义 6.2（结构因果模型） 结构因果模型（SCM）$\mathfrak{C} := (\mathcal{S}, P_{\mathbf{N}})$ 由 d 个（结构）赋值构成的集合 $\mathcal{S}$：

$$X_j := f_j(\mathbf{PA}_j, N_j), \qquad j = 1, \dots, d, \tag{6.1}$$

以及噪声变量上的联合分布 $P_{\mathbf{N}} = P_{N_1, \dots, N_d}$ 组成. 这里 $\mathbf{PA}_j \subseteq \{X_1, \dots, X_d\} \setminus \{X_j\}$ 称为 X_j 的父变量；我们要求噪声变量联合独立，即 $P_{\mathbf{N}}$ 是乘积分布.

SCM 的图 $\mathcal{G}$ 可以这样获得：为每个 X_j 创建一个顶点，并从 $\mathbf{PA}_j$ 中的每个父变量向 X_j 画有向边，即从式 (6.1) 右侧出现的每个变量 X_k 向 X_j 画有向边（见图 6.1）. 此后假设该图无环.

$$
\begin{aligned}
X_1 &:= f_1(X_3, N_1)\\
X_2 &:= f_2(X_1, N_2)\\
X_3 &:= f_3(N_3)\\
X_4 &:= f_4(X_2, X_3, N_4)\\
N_1, \dots, N_4 &\text{ 联合独立；} \mathcal{G} \text{ 无环}
\end{aligned}
$$

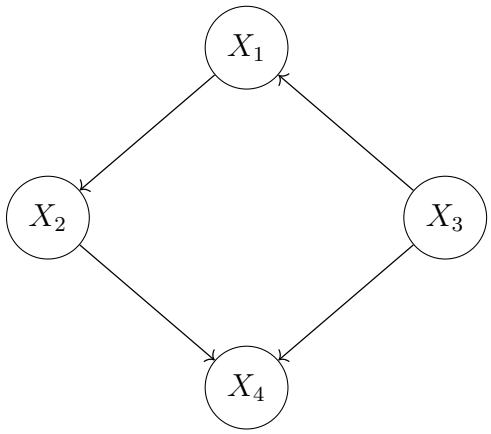


图 6.1：一个 SCM（左）及其对应的图（右）. 因果序 π 只有一个，满足 $3 \mapsto 1,\ 1 \mapsto 2,\ 2 \mapsto 3,\ 4 \mapsto 4$.

我们有时不仅将 $\mathbf{PA}_j$ 的元素称为父变量，也称它们为 X_j 的直接原因，并将 X_j 称为其每个直接原因的直接结果. SCM 也称为（非线性）SEM.

虽然部分术语是因果性的（“直接原因” 与 “直接结果”），定义 6.2 是纯数学定义. 第 6.8 节将讨论它作为真实系统模型的作用.

SCM 是将因果推理和因果学习形式化的关键. 首先说明 SCM 蕴含观测分布. 但与通常的概率模型不同，它们还蕴含干预分布（第 6.3 节）与反事实（第 6.4 节）；见图 6.2.

命题 6.3（蕴含分布） SCM $\mathfrak{C}$ 在变量 $\mathbf{X} = (X_1, \dots, X_d)$ 上定义唯一分布，使得对 $j = 1, \dots, d,\ X_j = f_j(\mathbf{PA}_j, N_j)$ 在分布意义下成立. 我们将其称为蕴含分布 $P_{\mathbf{X}}^{\mathfrak{C}}$，有时写作 $P_{\mathbf{X}}$.

证明见附录 C.2. 它将从联合分布采样 n 个数据点的过程（“祖先采样”）形式化：首先生成独立同分布样本 $\mathbf{N}^1, \dots, \mathbf{N}^n \sim P_{\mathbf{N}}$，然后依次使用结构赋值（从源节点开始，再到至多有一个父节点的节点，依此类推），生成独立同分布数据点 $\mathbf{X}^1, \dots, \mathbf{X}^n \sim P_{\mathbf{X}}$. 译注：此处按父节点总数递增的源文描述，本身不足以规定有效的祖先采样顺序；必须采用拓扑顺序，即仅在一个节点的全部父节点已赋值之后才计算它. 例如 $A \to C \leftarrow B$、$C \to D$ 中，D 只有一个父节点，却必须晚于有两个父节点的 C 计算. 若源文意指逐轮删除已采样节点，则还需明确该约定；原作者意图未知.

应当将结构赋值 (6.1) 理解为一组赋值或函数（而非一组数学方程），它告诉我们某些变量如何决定另一些变量. 因此我们更愿意避免使用文献中常用的 “结构方程” 一词.

代码片段 6.4 以下代码从具有图 6.1 所示形式的 SCM 生成独立同分布样本：结构赋值为 $f_1(x_3, n) = 2x_3 + n$、$f_2(x_1, n) = (0.5x_1)^2 + n$、$f_3(n) = n$、$f_4(x_2, x_3, n) = x_2 + 2\sin(x_3 + n)$，联合独立的噪声变量分别服从正态、卡方、均匀和正态分布.

```
# generate a sample from the distribution entailed by the SCM
set.seed(1)
X3 <- runif(100)-0.5
X1 <- 2*X3 + rnorm(100)
X2 <- (0.5*X1)^2 + rnorm(100)^2
X4 <- X2 + 2*sin(X3 + rnorm(100))
```

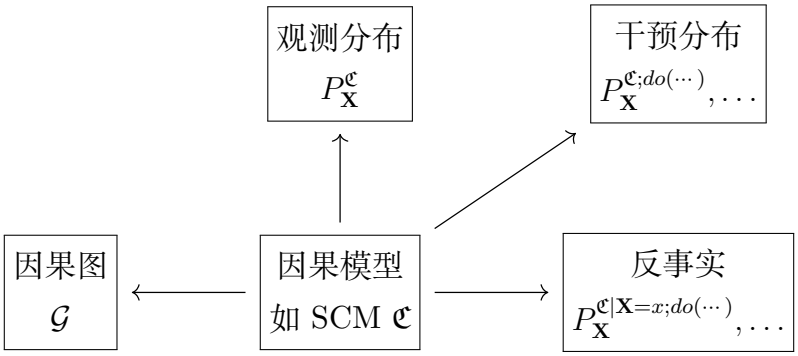


图 6.2: 作为因果模型的 SCM 不仅对观测分布 P 建模（命题 6.3），还对干预分布（第 6.3 节）和反事实（第 6.4 节）建模.

注 6.5（线性有环赋值） 本书主要关注无环结构. 现在简要讨论赋值导致有环结构的线性 SCM；这类模型已经得到充分理解［Lauritzen 和 Richardson, 2002；Lacerda 等, 2008；Hyttinen 等, 2012］. 我们着重于直觉，不作形式处理. 线性情形的更多细节见 Hyttinen 等 [2012]，非线性情形见 Mooij 等 [2011] 和 Bongers 等 [2016].

记 $\mathbf{X} = (X_1, \ldots, X_d)$，考虑赋值

$$\mathbf{X} := B\mathbf{X} + \mathbf{N},$$

其中 B 是允许有环结构的 $d \times d$ 矩阵，噪声向量 $\mathbf{N} = (N_1, \ldots, N_d) \sim P_{\mathbf{N}}$. 形式上，如果 $I - B$ 可逆，则对 $\mathbf{N}$ 的每个值，上式诱导 $\mathbf{X}$ 的唯一解：

$$\mathbf{X} = (I - B)^{-1}\mathbf{N} \tag{6.2}$$

（另见问题 3.8）. 式 (6.2) 显然定义了 $\mathbf{X}$ 的联合分布. 但它的（因果）解释是什么?

一种可能是将其解释为平衡过程的结果. 考虑随机变量序列 $\mathbf{X}_t$，它是以下迭代的解：

$$\mathbf{X}_t := B\mathbf{X}_{t-1} + \mathbf{N}, \qquad t = 1, 2, \ldots. \tag{6.3}$$

若 $t \to \infty$ 时 $B^t \to 0$，则序列 $\mathbf{X}_t$ 收敛；这等价于 B 的特征值位于单位圆内. 该条件严格强于 $I - B$ 可逆（见问题 6.60）. 如果满足该条件，极限的分布与式 (6.2) 诱导的分布相同；见问题 6.61.

在式 (6.3) 中，每个时间步都加上同一个噪声实现值. 如果改为每一步更新噪声，$\mathbf{X}_t$ 的极限分布就会改变：

$$\mathbf{X}_t := B\mathbf{X}_{t-1} + \mathbf{N}_{t-1}, \qquad t = 1, 2, \ldots, \tag{6.4}$$

其中 $\mathbf{N}_1, \mathbf{N}_2, \ldots$ 是 $\mathbf{N}_t$ 的独立同分布副本. 这可以视为时间序列情形，将在第 10.2 节讨论.

命题 6.3 表明每个 SCM 都蕴含一个分布. 反过来呢? 任意分布是否都由某个 SCM 蕴含? 事实上，后文（命题 7.1）将看到，每个分布都可以由图结构为完全 DAG 的 SCM

诱导（如果任意两个顶点之间都有连接，则称 DAG 是完全的）. 这意味着，SCM 的（观测）模型类，即 SCM 能够诱导的分布集合，是所有分布的集合.

SCM 的定义容许某个变量出现在结构赋值右侧，却不影响左侧的变量. 尽管这种父子关系在某种意义上是 “不活动的”，它仍作为一条边出现在对应图中. 形式上，我们通过以下注记排除这一情形：

注 6.6（SCM 的结构极小性） 定义 6.2 可以读成区分下列两个 SCM：

$$\mathcal{S}_1:\ X := N_X,\ Y := 0 \cdot X + N_Y \qquad \text{和} \qquad \mathcal{S}_2:\ X := N_X,\ Y := N_Y,$$

尽管显然 $0 \cdot X = 0$. 这与我们的直觉矛盾. 因此我们添加要求：函数 f_j 依赖其所有输入参数. 用数学语言说，只要存在 $k \in \{1, \dots, d\}$ 和函数 g，使得

$$f_k(pa_k, n_k) = g(pa_k^*, n_k), \qquad \forall pa_k,\ \forall n_k \text{ 满足 } p(n_k) > 0, \tag{6.5}$$

其中 $\mathbf{PA}_k^* \subsetneq \mathbf{PA}_k$，我们就选择后一个表示. 因而，在上例中我们会选择 $\mathcal{S}_2$ 而不是 $\mathcal{S}_1$. 后文将看到，这两个 SCM 确实可以视为相同：它们蕴含相同的观测分布、干预分布[2]和反事实（见第 6.8 节）.

此外，存在唯一的表示使每个函数的输入数量最小. 尽管这一陈述看似可信，我们仍在附录 C.3 中形式证明. 我们说这样的（最小）SCM 满足结构极小性.[3] 此后，我们假设结构极小性成立. 例如，与忠实性（第 6.5 节）相反，这不是关于底层世界的假设，而是避免冗余描述的约定.

注 6.7（与常微分方程的关系） 在注 6.5 中，我们已经看到 SCM 与离散时间模型的联系；现在简要讨论连续时间模型. 在物理系统中，我们常常预期因果关系由耦合微分方程组支配. 微分方程组 $\dot{\mathbf{X}} = f(\mathbf{X})$ 可以近似表示为赋值 $\mathbf{X}_{t+\Delta t} := \mathbf{X}_t + \Delta t \cdot f(\mathbf{X}_t)$，其中 $\Delta t > 0$ 很小；因此它包含细粒度时间尺度上因果结构的信息. 干预可以在物理上实现为将某个变量拉向期望值的强迫项.

在某些稳定性假设下，可以通过分析平衡态的行为，以不依赖时间的方式考察干预效果. 这蕴含一个 SCM，描述该动力系统的平衡态如何响应对可观测量的物理干预 [Mooij 等, 2013]. 在此 SCM 中，变量不再描述特定时刻的测量. 在这一现象学层面，原有时间结构消失. 该框架原则上也适用于有环结构，但尚未处理随机情形；理论被限制在确定性关系内. 这一不足很重要，因为不确定性可能来自多个来源，包括对微分方程参数或初始条件的不完全了解，以及一如既往的混杂. 我们不进一步讨论如何从微分方程导出现象学结构方程，而是引荐一些文献 [例如 Dash, 2005；Hansen 和 Sokol, 2014].

提出这一注记的主要动机是避免一个常见误解. 有时人们认为，明确指定变量所指的确切时间之后，因果推断的部分任务就变得不再必要. 这一观点尤其受到物理学的支持，因为在物理学中，每次测量通常都可以唯一对应到进行测量的时空点. 然而，这些论证表明，即使物理学中的变量也不总是指时间上定义明确的观测——例如，它们可能来自一个平衡情景.

[2]我们不允许保持结构赋值中的函数不变而只改变噪声分布的干预；见式 (6.5).

[3]这个术语与因果极小性（定义 6.33）不同. 因果极小性蕴含结构极小性（命题 6.49），反之则不成立；见问题 6.57.

6.3 干预

现在我们准备对系统中的干预建模. 直观地说，例如对变量 X_2 进行干预，将其设为抛硬币的二元结果时，我们预期这一干预会使系统的分布相对于此前没有干预时的行为发生变化. 此外，即使变量 X_2 以前受到其他变量的因果影响，现在它也只受到抛硬币的影响：它的因果父变量已经改变.

形式上，我们从 SCM $\mathfrak{C}$ 构造干预分布. 方法是修改 $\mathfrak{C}$ 并考虑新蕴含的分布. 一般而言，干预分布不同于观测分布.

定义 6.8（干预分布） 考虑 SCM $\mathfrak{C} := (\mathcal{S}, P_{\mathbf{N}})$ 及其蕴含分布 $P_{\mathbf{X}}^{\mathfrak{C}}$. 我们替换一个（或多个）结构赋值，得到新的 SCM $\widetilde{\mathfrak{C}}$. 假设我们将 X_k 的赋值替换为

$$X_k := \widetilde{f}(\widetilde{\mathbf{PA}}_k, \widetilde{N}_k).$$

我们将新 SCM 蕴含的分布称为干预分布，并称其结构赋值被替换的变量受到干预. 将新分布记为[4]

$$P_{\mathbf{X}}^{\widetilde{\mathfrak{C}}} =: P_{\mathbf{X}}^{\mathfrak{C};do(X_k := \widetilde{f}(\widetilde{\mathbf{PA}}_k, \widetilde{N}_k))}.$$

$\widetilde{\mathfrak{C}}$ 的噪声变量集合现在同时包含一些 “新” 的 $\widetilde{N}$ 与一些 “旧” 的 N，要求它们全部联合独立.

当 $\widetilde{f}(\widetilde{\mathbf{PA}}_k, \widetilde{N}_k)$ 在实数值 a 上产生点质量时，我们简记为 $P_{\mathbf{X}}^{\mathfrak{C};do(X_k:=a)}$，并称之为原子干预.[5] 如果干预满足 $\widetilde{\mathbf{PA}}_k = \mathbf{PA}_k$，即直接原因仍为直接原因，则称其为不完美干预.[6] 这是随机干预 [Korb 等, 2004] 的一个特例，在随机干预中，被干预变量的边缘分布具有正方差.

我们要求新 SCM $\widetilde{\mathfrak{C}}$ 的图无环；因此允许的干预集合取决于 $\mathfrak{C}$ 所诱导的图.

代码片段 6.9 以下代码从一个干预分布采样. 考虑代码片段 6.4 中的 SCM $\mathfrak{C}$，进行干预 $do(X_2 := 3)$，即从分布 $P_{\mathbf{X}}^{\mathfrak{C};do(X_2:=3)}$ 生成独立同分布样本.

```
# generate a sample from the intervention distribution
set.seed(1)
X3 <- runif(100)-0.5
X1 <- 2*X3 + rnorm(100)
# old:
# X2 <- (0.5*X1)^2 + rnorm(100)^2
X2 <- rep(3,100)
X4 <- X2 + 2*sin(X3 + rnorm(100))
```

[4]尽管只要不引入环，父变量集合就可以任意改变，我们主要考虑新父变量集合 $\widetilde{\mathbf{PA}}_k$ 为空或等于 $\mathbf{PA}_k$ 的干预.

[5]这也被称为理想干预、结构干预 [Eberhardt 和 Scheines, 2007]、手术式干预 [Pearl, 2009]、独立干预或确定性干预 [Korb 等, 2004].

[6]它也称为参数干预 [Eberhardt 和 Scheines, 2007]、依赖干预 [Korb 等, 2004]，或简称机制改变 [Tian 和 Pearl, 2001]. 关于软干预这一术语，见 Eberhardt 和 Scheines [2007]、Eaton 和 Murphy [2007] 和 Markowetz 等 [2005].

事实表明，干预概念是对分布差异建模、理解因果关系的有力工具. 我们尝试用一些例子说明这一点.

例 6.10（预测变量和干预目标） 本例讨论预测，说明某些变量尽管可能是目标变量 Y 的良好预测变量，对它们进行干预却可能使目标变量不受影响. 考虑 SCM $\mathfrak{C}$:

$$\begin{aligned} X_1 &:= N_{X_1}, \\ Y &:= X_1 + N_Y, \\ X_2 &:= Y + N_{X_2}, \end{aligned}$$

其图为 $X_1 \to Y \to X_2$；其中 $N_{X_1}, N_Y \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$，$N_{X_2} \sim \mathcal{N}(0, 0.1)$，三者联合独立. 假设我们希望从 X_1, X_2 预测 Y. 显然，X_2 比 X_1 是更好的 Y 预测变量；例如，不含 X_2 的线性模型所导致的均方误差，比不含 X_1 的线性模型要（显著）大. 然而，如果我们希望改变 Y，对 X_2 的干预没有用:

$$P_Y^{\mathfrak{C};do(X_2:=\widetilde{N})} = P_Y^{\mathfrak{C}} \qquad \text{对所有变量} \widetilde{N};$$

换言之，不论对 X_2 的干预有多强，Y 的分布都不受影响. 但对 X_1 的干预确实改变 Y 的分布:

$$P_Y^{\mathfrak{C};do(X_1:=\widetilde{N})} = \mathcal{N}\big(\mathbb{E}[N_Y] + \mathbb{E}[\widetilde{N}], \operatorname{var}[N_Y] + \operatorname{var}[\widetilde{N}]\big) \neq P_Y^{\mathfrak{C}}$$

如果 $P_{\widetilde{N}} \neq P_{N_{X_1}}$.

译注：本例源文对任意 $\widetilde{N}$ 写高斯形式的干预后分布；若干预噪声非高斯，其与独立高斯噪声之和一般不高斯，甚至未必有有限矩. 该高斯陈述须在适当噪声条件下使用，原式不改.

这个例子还可用于说明，干预通常不同于条件化:

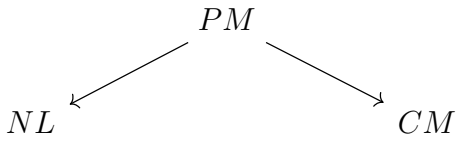
$$p_Y^{\mathfrak{C};do(X_2:=x)}(y) = p_Y^{\mathfrak{C}}(y) \neq p_Y^{\mathfrak{C}}(y \mid X_2 = x).$$

例 6.11（近视） 以下案例是统计依赖被错误解释为直接因果关系的众多例子之一. 在背景知识很少时，人似乎尤其容易作出这种错误的因果结论. 一项研究发现儿童房间使用夜灯与近视发生之间存在依赖［Quinn 等, 1999，第 113 页］. 作者谨慎地表示该研究 “并未确立因果联系”，但接着补充道：“关联的统计强度……确实表明，幼儿时期每天缺少一段黑暗时间是近视发展的潜在诱发因素.” 基于这些发现，有人申请了专利［Peterson, 2005］. 它暗示，如果对夜灯变量进行干预，就会改变发生近视的概率.

随后，Gwiazda 等 [2000] 和 Zadnik 等 [2000] 发现，这种相关源于儿童的父母是否近视. 他们认为，近视父母更可能在儿童房间放夜灯，同时儿童遗传这一状况的风险也增加. 因此，假设底层（“正确的”）SCM 具有如下形式:

$$\mathcal{S}: \quad \begin{cases} PM := N_{PM}, \\ NL := f(PM, N_{NL}), \\ CM := g(PM, N_{CM}), \end{cases}$$

其中 PM 表示父母近视，NL 表示夜灯，CM 表示儿童近视. 对应的图为



Quinn 等 [1999] 发现 $NL \not\perp\!\!\!\perp CM$，这与模型一致（假设忠实性成立，见定义 6.33）. 现在将 NL 的结构赋值替换为 $NL := \widetilde{N}_{NL}$；例如 $\widetilde{N}_{NL}$ 可以等概率随机分配三种夜灯条件（“黑暗”、“夜灯”、“房间灯光”）之一. 在相应干预分布 $P^{\mathfrak{C};do(NL:=\widetilde{N}_{NL})}_{NL,CM}$ 中，我们会发现 $NL \perp\!\!\!\perp CM$，因为 $CM := g(N_{PM}, N_{CM})$. 这与 $\widetilde{N}_{NL}$ 的分布无关. 我们称 NL 对 CM 没有因果效应.

受例 6.11 最后陈述的启发，我们定义总因果效应的存在［参见 Pearl, 2009 的“总因果效应”］.

定义 6.12（总因果效应） 给定 SCM $\mathfrak{C}$，从 X 到 Y 存在总因果效应，当且仅当对于某个随机变量 $\widetilde{N}_X$，

$$X \not\perp\!\!\!\perp Y \quad \text{在} P^{\mathfrak{C};do(X:=\widetilde{N}_X)}_{X} \text{ 中成立.}$$

译注：源定义在描述 X, Y 独立的干预分布时下标印为 P_X，而后面命题 *6.13(iv)* 写 $P_{X,Y}$. 此处保留原记号差异；仅单变量边缘分布不能单独表达二变量独立性.

除了定义 6.12，还有其他概念可以直观地描述总因果效应的存在. 但事实表明，人们可能想到的大多数陈述都是等价的. 下述命题在附录 C.4 中证明.

命题 6.13（总因果效应） 给定 SCM $\mathfrak{C}$，以下陈述等价：

(i) 从 X 到 Y 存在总因果效应.

(ii) 存在 $x^{\triangle}, x^{\star}$，使得 $P^{\mathfrak{C};do(X:=x^{\triangle})}_{Y} \neq P^{\mathfrak{C};do(X:=x^{\star})}_{Y}$.

(iii) 存在 $x^{\triangle}$，使得 $P^{\mathfrak{C};do(X:=x^{\triangle})}_{Y} \neq P^{\mathfrak{C}}_{Y}$.

(iv) 对任何其分布具有全支撑的 $\widetilde{N}_X$，$X \not\perp\!\!\!\perp Y$ 在 $P^{\mathfrak{C};do(X:=\widetilde{N}_X)}_{X,Y}$ 中成立.

译注（命题的适用边界）：以上四条按源书原样保留，但在任意可测机制的一般类中，*(iv)* 的全支撑要求不足以保证所称等价. 取相互独立的标准高斯噪声，令 $X := N_X$、$Y := \mathbf{1}_{\{X=0\}} + N_Y$. 观测联合分布具有处处为正的高斯乘积密度；原子干预 $do(X := 0)$ 与 $do(X := 1)$ 分别使 Y 服从 $N(1,1)$ 与 $N(0,1)$，但独立标准高斯干预以概率一避开 0，从而使 X, Y 独立. 因此，全拓扑支撑甚至处处为正的光滑干预密度也可能看不见局限于零测输入集的机制差异；需额外的机制 / 干预律正则性，或适当的离散正性条件，不能仅凭任选观测条件密度版本的连续性补足.

译注（混杂边界）：含混杂时，*(iii)* 与 *(i)*、*(ii)* 也不一般等价；观测边缘与干预边缘不同，并不单独建立定义 *6.12* 所指的总因果效应. 附录 *C.4* 的译注给出严格正的有限反例，并指出源证明中另一条无条件边缘等式的错误. 故此处不能将整个等价性视为已在原文所述一般类中证明；原作者可能意指的附加假设未知.

不出所料，总因果效应的存在与对应图中有向路径的存在有关. 但二者并非一一对应：有向路径是总因果效应的必要条件，却不是充分条件.

命题 6.14（总因果效应的图论判据） 假设给定 SCM $\mathfrak{C}$ 及对应图 $\mathcal{G}$.

(i) 如果不存在从 X 到 Y 的有向路径，则不存在总因果效应.

(ii) 有时存在有向路径却没有总因果效应.

证明见附录 C.5.

例 6.15（随机试验） 随机试验实现了因果效应的定义. 在这类研究中，按照 $\widetilde{N}_T$ 随机给患者分配治疗 T，并例如观测（二元）康复变量 R. 假设 T 取三个可能值（$T=0$：不服药；$T=1$：安慰剂；$T=2$：待研究药物），而 $\widetilde{N}_T$ 从这三种可能中随机选择一个：$P(\widetilde{N}_T=0)=P(\widetilde{N}_T=1)=P(\widetilde{N}_T=2)=1/3$. 在 SCM 中，这种随机化建模为观测来自分布

$$P_{\mathbf{X}}^{\mathfrak{C};do(T:=\widetilde{N}_T)}$$

的数据.（这里 $\mathfrak{C}$ 表示未经随机化的原始 SCM.）如果此时仍发现治疗与康复相依，我们就得出 T 对康复具有总因果效应的结论. 但也可能发现，无论药物类型如何都存在总因果效应. 图 6.3 给出了简化描述. 患者服用药片时，不论其成分如何，其心理状态（P）都会改变，进而影响康复. 假设安慰剂和待研究药物的这种安慰剂效应相同，即 P 的结构赋值满足

$$f_P(T=0,N_P)\neq f_P(T=1,N_P)=f_P(T=2,N_P).$$

在药物研究中，我们更关心生化效应而非安慰剂效应. 因此将随机化限制为只在安慰剂与待研究药物上有支撑，即 $P(\widetilde{N}_T=0)=0$. 如果此时仍看到治疗 T 与康复 R 相依，这必定源于生化效应.

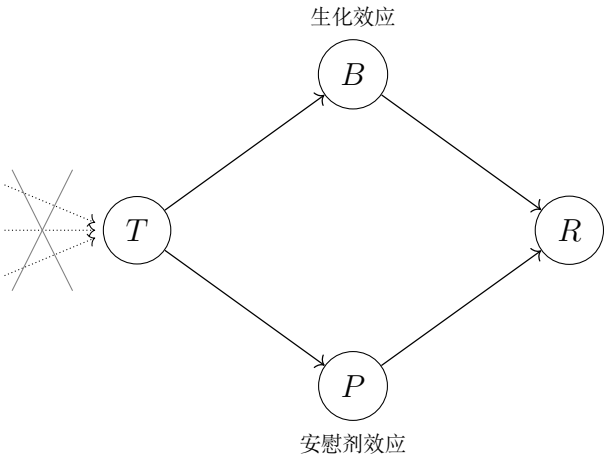


图 6.3: 随机研究的简化描述. T 表示治疗，P, B 分别表示患者心理状态和某个生化状态，R 表示患者是否康复. 对 T 进行随机化消除任何其他变量对 T 的影响，因此 T 和 R 之间不可能存在隐藏共同原因. 我们区分经由 P 的安慰剂效应与经由 B 的生化效应.

使用随机试验进行因果学习的思想曾由 Peirce [1883]、Peirce 和 Jastrow [1885]，后来又由 Neyman［原文的翻译和编辑版本见 Splawa-Neyman 等, 1990］和 Fisher [1925] 以不同数学语言描述. 其中大多数工作涉及农业应用.

一个早期随机试验例子由 James Lind 完成. 18 世纪，英国因坏血病损失的士兵多于因敌军行动损失的士兵；当时维生素 C 及其与坏血病的关系尚不为人所知. 苏格兰医生 James Lind（1716–1794）曾在船上担任外科医生，对该试验有如下记述［转引自 Bhatt, 2010］：

> 1747 年 5 月 20 日，我在海上的 Salisbury 号船上挑选了十二名坏血病患者. 我尽可能使他们的病情相近. 他们通常都有牙龈腐烂、斑点和倦怠，膝盖无力……其中两人各被安排每日饮用一夸脱苹果酒. 另两人每日三次服用二十五滴硫酸酏剂……另两人每日三次服用两匙醋……病情最重的两人接受海水疗程……另两人每日各得到两个橙子和一个柠檬……剩余两人服用……一名医院外科医生推荐的药膏……结果是，橙子和柠檬带来了最迅速、最明显的良好效果；其中一人在六天结束时已能执勤.

读者会注意到，这项试验并非完全随机，但它的历史趣味弥补了这一点.

例 6.16（肾结石） 表 6.1 展示一个著名的肾结石康复数据集［Charig 等, 1986］. 700 名患者中，一半接受开放手术（治疗 $T = a$，康复率 78%），另一半接受经皮肾镜取石术（$T = b$，康复率 83%）；后者是一种经小穿刺口移除肾结石的手术. 如果除了总体康复率外一无所知，并忽略例如副作用，那么许多人需要决定时会偏好治疗 b. 更仔细观察数据，可以将肾结石分为小结石和大结石. 我们发现开放手术在两个类别中都表现更好. 应如何处理这一结论反转?

首先给出直观解释. 大结石比小结石更严重（见表 6.1），而治疗 a 处理的这类困难病例多得多，尽管分配给 a, b 的患者总数相同. 因此，在总体中治疗 a 看起来可能不如 b，但在两个子组中都更好. 例如，如果医生预期治疗 a 比治疗 b 更好，就可能以更高概率将困难病例分配给治疗 a，从而产生分配不平衡.

另一种观点是使用干预语言来表述我们真正关心的精确问题. 问题不是在这项特定研究中治疗 $T = a$ 还是 $T = b$ 更成功，而是分别强制所有患者接受治疗 a 或 b 时两种治疗如何比较，或者在每位患者被随机分配到一种治疗时比较康复率. 这三种情形涉及不同于观测分布 $P_{\mathbf{X}}$ 的干预分布；具体对应 $P^{\mathfrak{C};do(T:=a)}$、$P^{\mathfrak{C};do(T:=b)}$ 或 $P^{\mathfrak{C};do(T:=\widetilde{N}_T)}$. 我们将在例 6.37 计算这些干预分布，并看到为什么应当偏好治疗 a 而不是 b. 这个数据集是 Simpson 悖论［Simpson, 1951］的著名例子（第 9.2 节）. 事实上，它与其说是悖论，不如说是混杂影响，即隐藏共同原因所导致的结果.

	总体	小结石患者	大结石患者
治疗 a：开放手术	78% (273/350)	**93% (81/87)**	**73% (192/263)**
治疗 b：经皮肾镜取石术	**83% (289/350)**	87% (234/270)	69% (55/80)

表 6.1: Simpson 悖论的经典例子. 表中报告两种肾结石治疗的成功率［Bottou 等, 2013; Charig 等, 1986, 表 I 和 II］. 尽管治疗 b 的总体成功率看似更好（粗体为各列最大值），它在小结石和大结石患者中都不如治疗 a（见例 6.37 和第 9.2 节）.

如果对数据进行显著性检验（例如比例检验或 χ^2 独立性检验），则方法间差异在 5% 显著性水平下不显著. 但注意这不是本例重点. 将表 6.1 每个条目乘以 10 后，结果就会具有统计显著性. 我们还着重考虑康复 R，忽略了同样可能影响治疗决定的副作用.

现在介绍将干预形式化的另一种方法，例如见 Dawid [2015] 或 Pearl [2009，第 3.2.2 节]. 我们扩充 SCM $\mathfrak{C}$，从而扩充其 DAG，加入无父节点的节点 $I_1, I_2, \ldots, I_d$，称为 “干预变量”，它们分别指向 $X_1, \ldots, X_d$. 为简单起见，这里只讨论对单个节点的干预. 每个 I_j 要么取值 $idle$，要么取 X_j 可以取得的某个值 x_j. 此时 $I_j = x_j$ 表示 X_j 被设为 x_j，而 $I_j = idle$ 表示未对 X_j 干预. 相应地，将结构赋值 $X_j := f_j(\mathbf{PA}_j, N_j)$ 替换为

$$X_j := \begin{cases} f_j(\mathbf{PA}_j, N_j), & I_j = idle, \\ I_j, & \text{其他情况}, \end{cases}$$

并加入 $I_1, \ldots, I_d$ 的赋值，它们都只由噪声变量决定. 在给 I_j 的所有可能取值赋予非零概率（或概率密度）之后，原始 SCM $\mathfrak{C}$ 蕴含的干预概率就变成扩充后的 SCM $\mathfrak{C}^*$ 中的通常条件概率：

$$P_Y^{\mathfrak{C};do(X_j:=x_j)} = P_{Y|I_j=x_j}^{\mathfrak{C}^*},$$

见注 6.40. 此外，关于对某变量的干预是否改变某个目标变量分布的陈述，也变成通常的统计独立性陈述.

6.4 反事实

反事实的定义和解释在文献中受到广泛关注. 它们处理如下情况：假设你正在玩扑克，起手牌是梅花 J 和梅花 3（有时称为 “lumberjack”，即树和 J 的双关）；你估计获胜概率太小，不想损失更多钱，于是停止游戏（“弃牌”）. 接着三张牌正面朝上发到公共牌区（“翻牌”），分别为梅花 4、梅花 Q 和梅花 2. 一种典型反事实反应是：“如果我继续留在牌局中，机会就会很好.”（五张同花色的牌称为 “同花”，牌型排名第五高；甚至有可能得到排名第二高的 “同花顺”.）这一陈述将观测数据（手牌和翻牌）纳入模型，然后分析一个干预分布（留在牌局），其中其余环境保持不变（相同的牌）. 在形式上，这对应于（通过条件化）更新 SCM 的噪声分布，再进行干预.

定义 6.17（反事实） 考虑节点为 $\mathbf{X}$ 的 SCM $\mathfrak{C} := (\mathcal{S}, P_{\mathbf{N}})$. 给定某些观测 $\mathbf{x}$，我们通过替换噪声变量的分布来定义反事实 SCM：

$$\mathfrak{C}_{\mathbf{X}=\mathbf{x}} := \left(\mathcal{S}, P_{\mathbf{N}}^{\mathfrak{C}|\mathbf{X}=\mathbf{x}}\right),$$

其中 $P_{\mathbf{N}}^{\mathfrak{C}|\mathbf{X}=\mathbf{x}} := P_{\mathbf{N}|\mathbf{X}=\mathbf{x}}$.[7] 新的噪声变量集合不一定仍然联合独立. 此时反事实陈述可视作新反事实 SCM 中的 do 陈述.

这一概念可以推广到只观测部分变量而非完整向量 $\mathbf{X} = \mathbf{x}$ 的情形.

例 6.18（计算反事实） 考虑 SCM：

$$\begin{aligned} X &:= N_X, \\ Y &:= X^2 + N_Y, \\ Z &:= 2 \cdot Y + X + N_Z, \end{aligned}$$

[7] 连续情形下该定义伴随测度论问题，因为条件分布通常只在零测集意义下确定. 为简单起见，我们将反事实限制于离散情形，即噪声分布具有概率质量函数的情况. 对有密度的连续变量，我们改为以 $\mathbf{X} \in A$ 为条件，其中 $P(\mathbf{X} \in A) > 0$，而不是以 $\mathbf{X} = \mathbf{x}$ 为条件.

其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{U}(\{-5,-4,\dots,4,5\})$，即它们在 -5 到 5 之间的整数上均匀分布. 假设我们观测到 $(X,Y,Z)=(1,2,4)$. 则 $P_{\mathbf{N}}^{\mathfrak{C}|\mathbf{X}=\mathbf{x}}$ 在 $(N_X,N_Y,N_Z)=(1,1,-1)$ 上放置点质量，因为这里所有噪声项都可从观测中唯一重构. 因此，我们得到反事实陈述（在 $(X,Y,Z)=(1,2,4)$ 的背景下）：“如果 X 是 2，Z 本会是 11.” 本书将这样的句子解释为：“如果 X 被设为 2，Z 本会是 11.” 数学上，这意味着 $P_Z^{\mathfrak{C}|\mathbf{X}=\mathbf{x};do(X:=2)}$ 在 11 上具有点质量. 同样得到 “如果 X 是 2，Y 本会是 5” 和 “如果 Y 是 5，Z 本会是 10”.

由于反事实的构造涉及多个步骤，其记号看起来相当复杂.[8] 希望以下图解能进一步澄清：

$$\underbrace{P}_{\substack{\text{4. 我们关心}\\ \text{的变量}Z}}{}_{Z}\overbrace{\mathfrak{C}}^{\text{1. 起始 SCM}}\overbrace{|\mathbf{X}=\mathbf{x}}^{\text{2. 观测数据}};\overbrace{do(Y:=2)}^{\text{3. 干预}}.$$

反事实陈述强烈依赖于 SCM 的结构. 例 6.19 展示两个 SCM，它们诱导相同的图、观测分布和干预分布，但蕴含不同反事实陈述. 后文我们将称这样的 SCM“概率和干预等价”，但不 “反事实等价”（见定义 6.47）.

例 6.19 令 $N_1, N_2 \sim \text{Ber}(0.5)$，$N_3 \sim \mathcal{U}(\{0,1,2\})$，且这三个变量联合独立. 即 N_1, N_2 服从参数 0.5 的 Bernoulli 分布，N_3 在 $\{0,1,2\}$ 上均匀分布. 我们定义两个不同 SCM. 首先考虑 $\mathfrak{C}_A$：

$$\begin{aligned}
X_1 &:= N_1,\\
X_2 &:= N_2,\\
X_3 &:= (\mathbf{1}_{N_3>0}\cdot X_1 + \mathbf{1}_{N_3=0}\cdot X_2)\cdot \mathbf{1}_{X_1\neq X_2} + N_3\cdot \mathbf{1}_{X_1=X_2}.
\end{aligned}$$

如果 X_1, X_2 取值不同，根据 N_3，我们选择 $X_3=X_1$ 或 $X_3=X_2$；否则 $X_3=N_3$. 现在 $\mathfrak{C}_B$ 只在后一种情况与 $\mathfrak{C}_A$ 不同：

$$\begin{aligned}
X_1 &:= N_1,\\
X_2 &:= N_2,\\
X_3 &:= (\mathbf{1}_{N_3>0}\cdot X_1 + \mathbf{1}_{N_3=0}\cdot X_2)\cdot \mathbf{1}_{X_1\neq X_2} + (2-N_3)\cdot \mathbf{1}_{X_1=X_2}.
\end{aligned}$$

两个 SCM 蕴含相同的观测分布，并且对任意可能干预也蕴含相同的干预分布.[9] 但两个模型在一个反事实陈述上不同. 假设观测到 $(X_1,X_2,X_3)=(1,0,0)$，并关心反事实问题：“如果 X_1 是 0，X_3 本会是多少？” 两个 SCM 都给出 $N_3=0$，因此在对 X_1 作反事实改变时，两个 SCM $\mathfrak{C}_A, \mathfrak{C}_B$ 对 X_3 的 “预测” 不同（分别为 0 和 2）.

前例有两方面含义：（1）两个 SCM 对应相同的因果图模型（见第 6.5.2 节）；在这个意义上，因果图模型不够丰富，无法预测反事实.（2）在第 6.8 节中，我们将干预分

[8] Pearl [2009] 使用稍简单的记号 $Z_y(u)$，其中下标 y 表示干预 $do(Y:=y)$，u 表示可能由例如 $\mathbf{X}=\mathbf{x}$ 所蕴含的关于误差项的额外信息；他将这些误差项记为 u.

[9] 本例的观测分布相对于底层图（这里为 $X_1 \to X_3 \leftarrow X_2$）满足因果极小性，见定义 6.33. 另一个例子见第 3.4 节；它较简单，但违反因果极小性.

布与真实世界的随机实验联系起来. 对于本例，我们不能使用随机试验或观测数据区分 $\mathfrak{C}_A$ 与 $\mathfrak{C}_B$. 因此，如果关心反事实陈述，就需要额外假设来区分二者.

注 6.20 现在总结反事实的一些性质.

(i) 反事实陈述不具有传递性. 在例 6.18 中，给定观测 $(X, Y, Z) = (1, 2, 4)$，我们发现："如果 X 是 2，Y 本会是 5"；"如果 Y 是 5，Z 本会是 10"；以及 "如果 X 是 2，Z 本不会是 10". 因此，我们不能简单地引入新变量（如 $\widetilde{X}, \widetilde{Y}$），将 "如果 X 是 2，Y 本会是 5" 解释为 "$\widetilde{X} = 2 \Rightarrow \widetilde{Y} = 5$" 形式的逻辑蕴含. 在前例中，不具有传递性源于从 X 到 Z 的直接联系，即存在不经过 Y 的从 X 到 Z 的路径. 对干预分布也有类似反例.

(ii) 人们常常以反事实思考："我当时应该坐火车"、"还记得我们在 2000 年 9 月 11 日飞往纽约的航班吗？想象一下如果我们晚一年乘坐那趟航班！" 或 "我们当时应该在 2014 年 12 月投资瑞士法郎！" 只是少数例子. 有趣的是，有时即使我们根据可获得信息作出了最优决定，也会这样想. 假设有人提出，如果猜对一次抛硬币的结果就给你 10,000 美元；你猜 "正面" 却输了. 有些人可能会想："我为什么没说反面？" 尽管他们完全不可能预知结果. Roese [1997]、Byrne [2007] 等讨论了反事实思维的心理学含义. 讨论反事实陈述是否包含有助于我们将来作出更好决定的信息很有趣，但超出本书范围；另见 Pearl [2009，第 4 章].

(iii) 我们也不讨论反事实在法律体系中的作用；反事实是否及如何应被作为判决基础，是一个有趣问题（见例 3.4）.

(iv) 人们很久以来就在思考反事实；它是历史学家常用的工具. 例如，Titus Livius 在公元前 25 年讨论了如果亚历山大大帝没有死在亚洲、而是进攻罗马会发生什么 [Geradin 和 Girgenson, 2011]. 保罗《哥林多前书》(7:29–7:31) 写道："弟兄们，我是说，时候减少了；从此以后，那有妻子的，要像没有妻子；哀哭的，要像不哀哭；喜乐的，要像不喜乐；买物的，要像无所得；用世物的，要像不尽用它."

(v) 可以把干预陈述看作（随机）实验的数学构造. 对反事实陈述，在真实世界中没有可与之相比的对应物. 可以推测，许多反事实陈述无法证伪，因此不应用于科学探究 [参见 Popper, 2002]. 但注意，有时我们可以作出可证伪的反事实陈述（例如事后弄清样本中相应实例的噪声项实际值；见例 3.4）. 此外，上述反事实是设定 SCM 的结果. 因此，另一个证伪目标也可以是 SCM，而不是某个给定的反事实陈述. 例如，可以利用 SCM 所涉及科学领域的方法；这样做可能可行，也可能不可行.[10]

这些注记可以看作供思考的材料. 我们不再深入讨论反事实陈述的解释，以及例如如何应当或可以在法庭案件中使用它们. 许多这样的考虑超出我们的专业领域. 这里转而引荐 Halpern [2016]，他讨论了某事件是另一事件的 "实际原因" 意味着什么.

[10] 注意，第 3.4 节所述的重新参数化自由度始终存在.

6.5 Markov 性、忠实性与因果极小性

6.5.1 Markov 性

Markov 性是图模型基础的一项常用假设. 当一个分布相对于某个图满足 Markov 性时，图编码了该分布中的某些独立性，我们可以利用它们进行高效计算或数据存储. 有向图和无向图都有 Markov 性，而两类图编码不同的独立性集合 [Koller 和 Friedman, 2009]. 但在因果推断中，我们主要关心有向图. 许多因果推断教材从假设 Markov 性开始；本书则假设底层 SCM 的存在. 我们将在命题 6.31 看到，这足以证明 Markov 性. 不过首先定义这一性质.

定义 6.21（Markov 性） 给定 DAG $\mathcal{G}$ 和联合分布 $P_{\mathbf{X}}$，称该分布满足：

(i) 关于 DAG $\mathcal{G}$ 的全局 Markov 性，如果对所有互不相交的顶点集 A, B, C，都有

$$A \perp\!\!\!\perp_{\mathcal{G}} B \mid C \quad \Rightarrow \quad A \perp\!\!\!\perp B \mid C$$

（符号 $\perp\!\!\!\perp_{\mathcal{G}}$ 表示 d 分离，见定义 6.1）；

(ii) 关于 DAG $\mathcal{G}$ 的局部 Markov 性，如果每个变量在给定父节点时独立于其非后代；

(iii) 关于 DAG $\mathcal{G}$ 的 Markov 因子分解性质，如果

$$p(\mathbf{x}) = p(x_1, \ldots, x_d) = \prod_{j=1}^{d} p(x_j \mid pa_j^{\mathcal{G}}).$$

对于最后这一性质，必须假设 $P_{\mathbf{X}}$ 具有密度 p；乘积中的因子称为因果 Markov 核，描述条件分布 $P_{X_j|\mathbf{PA}_j^{\mathcal{G}}}$.

事实表明，只要联合分布有密度，[11]这三种定义便等价.

定理 6.22（Markov 性的等价性） 如果 $P_{\mathbf{X}}$ 有密度 p，则定义 6.21 中所有 Markov 性均等价. 证明例如见 Lauritzen [1996] 的定理 3.27.

例 6.23 根据 (i) 或 (ii)，分布 P_{X_1,X_2,X_3,X_4} 相对于图 6.1 所示的图 $\mathcal{G}$ 满足 Markov 性，如果

$$X_2 \perp\!\!\!\perp X_3 \mid X_1 \qquad \text{且} \qquad X_1 \perp\!\!\!\perp X_4 \mid X_2, X_3,$$

或根据 (iii)，如果

$$p(x_1, x_2, x_3, x_4) = p(x_3)p(x_1 \mid x_3)p(x_2 \mid x_1)p(x_4 \mid x_2, x_3).$$

后文命题 6.31 将看到，SCM 所蕴含的分布相对于该 SCM 的图满足 Markov 性. 因此，图 6.1 左侧 SCM 蕴含的分布 P_{X_1,X_2,X_3,X_4} 确实满足这些条件. 直观地说，$X_2 \perp\!\!\!\perp X_3 \mid X_1$ 是合理的：考虑路径 $X_2 \leftarrow X_1 \leftarrow X_3$，如果已知 X_1，X_3 就不提供关于 X_2 的新信息. 在这个意义上，SCM 的图结构在联合分布中留下某些 “痕迹”.

[11]本书始终考虑相对于乘积测度的密度.

Markov 条件将图的分离陈述与条件独立性联系起来. 不过，不同的图可能编码完全相同的条件独立性集合.

定义 6.24（图的 Markov 等价性） 用 $\mathcal{M}(\mathcal{G})$ 表示相对于 $\mathcal{G}$ 满足 Markov 性的分布集合：

$$\mathcal{M}(\mathcal{G}) := \{P : P \text{ 相对于} \mathcal{G} \text{ 满足全局（或局部）Markov 性}\}.$$

如果 $\mathcal{M}(\mathcal{G}_1) = \mathcal{M}(\mathcal{G}_2)$，则两个 DAG $\mathcal{G}_1, \mathcal{G}_2$ 具有Markov 等价性（Markov equivalence）. 当且仅当二者具有相同的 d 分离集合时情形如此，这意味着 Markov 条件蕴含相同的（条件）独立性条件.

与某 DAG $\mathcal{G}$ Markov 等价的所有 DAG 组成的集合称为 $\mathcal{G}$ 的 Markov 等价类. 可以用一个称为完成的 PDAG、记为 CPDAG$(\mathcal{G}) = (V, E)$ 的图表示：当且仅当 Markov 等价类的某个成员包含（有向）边 (i, j) 时，它包含 $(i, j) \in E$；见图 6.4.

根据这一定义，确定两个 DAG 是否 Markov 等价似乎是非平凡问题. 幸而 Verma 和 Pearl [1991] 给出了简洁刻画，另见 Frydenberg [1990].

引理 6.25（Markov 等价的图论判据） 两个 DAG $\mathcal{G}_1, \mathcal{G}_2$ Markov 等价，当且仅当它们具有相同骨架和相同非道德结构.

这里，如果 DAG 中三个节点 A, B, C 满足 $A \to B \leftarrow C$，且 A, C 没有直接连接，则称它们构成非道德结构或 v 结构（见第 6.1 节）.

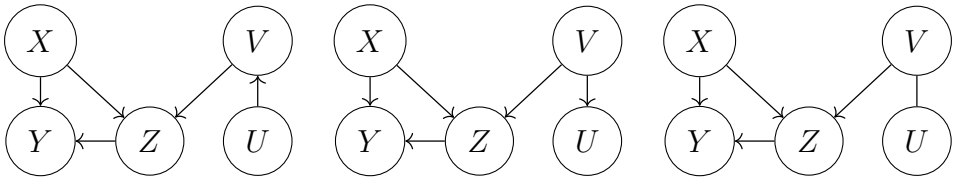


图 6.4: 两个 Markov 等价的 DAG（左、中）；它们是对应 Markov 等价类中仅有的两个 DAG，可由右侧 CPDAG 表示.

图 6.4 给出两个 Markov 等价图的例子（左和中）. 它们具有相同骨架，且都只有一个非道德结构：$X \to Z \leftarrow V$. 在对应 CPDAG（图右）中，并非所有有向边都是非道德结构的一部分. 例如，需要边 $Z \to Y$ 来避免出现 $Y \to Z \leftarrow V$ 这一 v 结构. 此外，$X \to Y$ 防止出现有向环.

现在介绍 Markov 毯这一图论概念 [Pearl, 1988]. 当试图根据所有其他变量的观测值预测目标变量 Y 时，该概念就会变得重要. 可以问：知道哪一个最小变量集合后，剩余变量对预测任务就不再相关?

定义 6.26（Markov 毯） 考虑 DAG $\mathcal{G} = (V, E)$ 和目标节点 Y. Y 的 Markov 毯是满足以下条件的最小集合 M：

$$Y \perp\!\!\!\perp_{\mathcal{G}} V \setminus (\{Y\} \cup M) \quad \text{给定} M.$$

如果 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 满足 Markov 性，则

$$Y \perp\!\!\!\perp V \setminus (\{Y\} \cup M) \quad \text{给定} M.$$

换言之，给定 M 后，其他变量不再提供关于 Y 的任何额外信息. 在理想化回归情形中，我们因此只需纳入 M 中的变量来预测 Y. 这并不意味着有限样本情形中其他变量无用. 如果 Y 对其 Markov 毯 M 的依赖与所用回归方法的先验或函数类不够匹配，添加 M 以外的变量可能改善对 Y 的预测.

对于 DAG，我们知道 Markov 毯的形式：它不仅包含父节点，还包含子节点与子节点的父节点 [Pearl, 1988]．

命题 6.27（Markov 毯） 考虑 DAG $\mathcal{G}$ 和目标节点 Y. 那么 Y 的 Markov 毯 M 包含其父节点、子节点和子节点的父节点：

$$M = \mathbf{PA}_Y \cup \mathbf{CH}_Y \cup \mathbf{PA}_{\mathbf{CH}_Y}.$$

译注：若 $\mathbf{PA}_{\mathbf{CH}_Y}$ 按通常定义包含 Y 本身，源式给出的 M 就含 Y，与前面要求分离集合相互不交的约定不符. 通常应去掉 Y 或另行声明集合约定；此处不静默修正式.

至此，我们将 Markov 性作为分布与图之间的关系讨论. 现在讨论它的一些因果含义. Markov 性可以用于论证 Reichenbach 的共同原因原则（原则 1.1）. 回忆该原则指出，当随机变量 X, Y 相依时，必定存在对此依赖的“因果解释”：

(i) X（可能间接地）导致 Y；或

(ii) Y（可能间接地）导致 X；或

(iii) 存在一个（可能未观测到的）共同原因 Z，（可能间接地）同时导致 X, Y.

这里我们尚未进一步指明“导致”的含义. 下述命题相对于一个较弱的“导致”概念，即有向路径的存在，为 Reichenbach 原则提供论证.

命题 6.28（Reichenbach 共同原因原则） 假设任意一对变量 X, Y 都能以下述意义嵌入一个更大系统：存在一个正确的 SCM，定义在包含 X, Y 的随机变量集合 $\mathbf{X}$ 上，其图为 $\mathcal{G}$. 那么 Reichenbach 的共同原因原则由 Markov 性得出. 如果 X, Y（无条件地）相依，则

(i) 或者存在从 X 到 Y 的有向路径；

(ii) 或者存在从 Y 到 X 的有向路径；

(iii) 或者存在节点 Z，从 Z 到 X、从 Z 到 Y 都有有向路径.

证明： 由 Markov 性，相依性意味着 $\mathcal{G}$ 中有一条连接 X, Y 的未阻断路径. 此路径不能包含碰撞点，否则会被空集阻断. 由于任何连接 X, Y 且不包含碰撞点的路径都必定具有 $X \to \cdots \to Y$、$X \leftarrow \cdots \leftarrow Y$ 或 $X \leftarrow \cdots \leftarrow Z \to \cdots \to Y$ 的形式，结论随之成立. □

注 6.29（选择偏差） 在 Reichenbach 原则中，我们从两个相依随机变量出发并得到有效陈述. 但在实际应用中，可能已经隐含地以第三个变量为条件（选择偏差）. 如例 6.30 所示，这可能导致 X, Y 相依，尽管上述三个条件都不成立（另见第 1.3 节最后一段）.

例 6.30（Berkson 悖论） 以下例子“为什么英俊的男人如此讨厌？”取自 Ellenberg [2014]，是 Berkson 悖论的一个实例 [Berkson, 1946]. 假设男性是否处于恋爱关系

($R = 1$) 仅由其是否英俊（$H = 1$）和是否友善（$F = 1$）决定. 更准确地说，假设正确的 SCM 具有如下形式：

$$\begin{aligned} H &:= N_H, \\ F &:= N_F, \\ R &:= \min(H, F) \oplus N_R, \end{aligned}$$

对应图为 $H \to R \leftarrow F$，其中 $N_H, N_F \overset{\text{iid}}{\sim} \text{Ber}(0.5)$，$N_R \sim \text{Ber}(0.1)$. 符号 $\oplus$ 表示模 2 加法. 在这一模型中，如果一名男性既英俊又友善，他很可能处于恋爱关系；否则他很可能单身. 从 SCM 可见，H, F 被假设为独立. 但如果只考虑没有处于恋爱关系的男性，即以 $R = 0$ 为条件，那么友善和英俊这两个特征就变得负相关. 如果某人英俊，他更可能不友善（否则他就会处于恋爱关系）. 我们有

$$F \not\perp\!\!\!\perp H \mid R = 0,$$

因而给定 R 时 F 不独立于 H.

如前所述，Pearl [2009] 在定理 1.4.1 中证明，由 SCM 诱导的分布 $P_{\mathbf{X}}$ 相对于其图满足 Markov 性［另见 Verma 和 Pearl, 1988］.

命题 6.31（SCM 蕴含 Markov 性） 假设 $P_{\mathbf{X}}$ 由图为 $\mathcal{G}$ 的 SCM 诱导. 那么 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 满足 Markov 性.

假设一个分布相对于因果图满足 Markov 性，有时称为因果 Markov 条件（causal Markov condition）；这要求先有因果图的概念. 对我们来说，因果图由底层 SCM 诱导. 另一方面，因果图模型将因果图作为因果推断的出发点.

6.5.2 因果图模型

我们将在第 6.6 节看到，要定义干预分布，通常只需知道观测分布和图结构. 因此，我们将因果图模型定义为由图和观测分布组成的二元组，其中分布相对于该图满足 Markov 性（因果 Markov 条件）. 不过，这里有一个微妙的技术问题：形式上，我们需要获得完整的条件分布. 例如，如果 $p(x_2 \mid x_1 = 3)$ 未定义（可能因为 $p(x_1 = 3) = 0$），我们就可能无法定义 $p^{do(X_1:=3)}(x_2)$. 这引出以下定义：

定义 6.32（因果图模型） 随机变量 $\mathbf{X} = (X_1, \ldots, X_d)$ 上的因果图模型包含一个图 $\mathcal{G}$ 和一组积分为 1 的函数 $f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}})$：

$$\int f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}}) \, \mathrm{d}x_j = 1.$$

这些函数通过

$$p(x_1, \ldots, x_d) = \prod_{j=1}^{d} f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}})$$

在 $\mathbf{X}$ 上诱导一个分布 $P_{\mathbf{X}}$，因此充当条件分布：$f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}}) = p(x_j \mid x_{\mathbf{PA}_j^{\mathcal{G}}})$. 因果图模型根据第 6.6 节的式 (6.8)、(6.9) 诱导干预分布. 在最一般形式下，可以定义

$$p^{do(X_k := q(\cdot \mid x_{\widetilde{\mathbf{PA}}_k}))}(x_1, \ldots, x_d) = \prod_{j \neq k} f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}}) \, q(\cdot \mid x_{\widetilde{\mathbf{PA}}_k}),$$

其中 $q(\cdot \mid x_{\widetilde{\mathbf{PA}}_k})$ 的积分为 1，且新的父变量不产生环.

如果 $\mathbf{X}$ 上的分布 $P_{\mathbf{X}}$ 相对于图 $\mathcal{G}$ 满足 Markov 性，并容许严格为正的连续密度 p，则二元组 $(P_{\mathbf{X}}, \mathcal{G})$ 通过 $f_j(x_j, x_{\mathbf{PA}_j^{\mathcal{G}}}) := p(x_j \mid x_{\mathbf{PA}_j^{\mathcal{G}}})$ 定义一个因果图模型.

为什么我们主要使用 SCM，而不仅使用图与 Markov 条件，即因果图模型？形式上，SCM 比其对应的图和分布包含严格更多的信息（例如反事实陈述），因此也比所有干预分布加观测分布所组成的族包含更多信息. 不过，这些额外信息是否有用是可以讨论的. 或许更重要的是，限制 SCM 中的函数类可以使因果结构可识别（见第 4.1.3–4.1.6 节和第 7.1.2 节）. 这些假设用 SCM 的语言比用图模型的语言更容易表述.

6.5.3 忠实性与因果极小性

上一小节讨论了 Markov 假设，它使我们能够从图结构读出独立性. 忠实性使我们能够从图结构推断依赖性.

定义 6.33（忠实性和因果极小性） 考虑分布 $P_{\mathbf{X}}$ 和 DAG $\mathcal{G}$.

(i) 如果对所有互不相交的顶点集 A, B, C 都有

$$A \perp\!\!\!\perp B \mid C \quad \Rightarrow \quad A \perp\!\!\!\perp_{\mathcal{G}} B \mid C,$$

则称 $P_{\mathbf{X}}$ 对 DAG $\mathcal{G}$ 满足忠实性（faithfulness）.

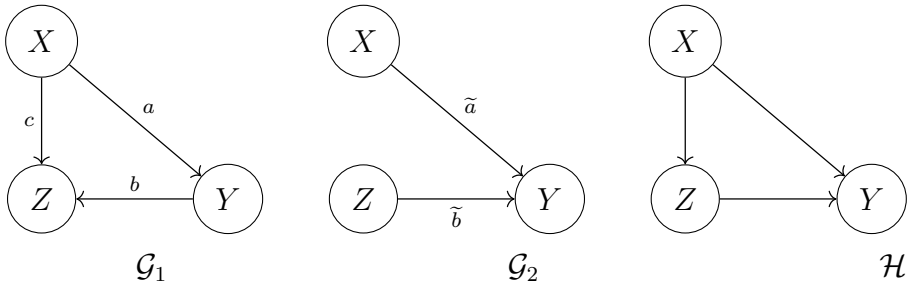
(ii) 如果一个分布相对于 $\mathcal{G}$ 满足 Markov 性，却不相对于 $\mathcal{G}$ 的任何真子图满足 Markov 性，则它相对于 $\mathcal{G}$ 满足因果极小性（causal minimality）.

第 (i) 部分给出的蕴含方向与全局 Markov 条件

$$A \perp\!\!\!\perp_{\mathcal{G}} B \mid C \quad \Rightarrow \quad A \perp\!\!\!\perp B \mid C$$

相反，见定义 6.21. 乍看之下忠实性并不十分直观. 现在给出一个相对于给定 DAG $\mathcal{G}_1$ 满足 Markov 性却不忠实的分布例子. 方法是让两条路径相互抵消，产生一种不由图结构蕴含的独立性.

例 6.34（违背忠实性） 考虑以下图：



首先考察对应左图 $\mathcal{G}_1$ 的线性高斯 SCM：

$$\begin{aligned} X &:= N_X, \\ Y &:= aX + N_Y, \\ Z &:= bY + cX + N_Z, \end{aligned}$$

其中正态分布噪声变量 $N_X \sim \mathcal{N}(0, \sigma_X^2)$、$N_Y \sim \mathcal{N}(0, \sigma_Y^2)$、$N_Z \sim \mathcal{N}(0, \sigma_Z^2)$ 联合独立. 这是图为 $\mathcal{G}_1$ 的线性高斯 SCM 的例子（见定义 6.2）. 现在如果

$$a \cdot b + c = 0, \tag{6.6}$$

则该分布不忠实于 $\mathcal{G}_1$，因为我们得到 $X \perp\!\!\!\perp Z$，但图结构并不蕴含这一独立性.[12] 读者可以容易地验证，存在一个 DAG 为 $\mathcal{G}_2$、诱导相同分布的 SCM.

为了在前例中获得额外独立性，我们不得不 “调节” 系数，使两条路径在式 (6.6) 中相互抵消. Spirtes 等 [2000，定理 3.2] 对线性模型表明，如果假设系数从正密度随机抽取，这种情况发生的概率为零.

例 6.34 中的分布忠实于 $\mathcal{G}_2$，但不忠实于 $\mathcal{G}_1$. 尽管如此，只要参数均非零，两个模型都满足因果极小性. 换言之，分布不相对于 $\mathcal{G}_1$ 或 $\mathcal{G}_2$ 的任何真子图满足 Markov 性，因为删除任何一条边都会对应一个在该分布中不成立的新（条件）独立性；注意 $\mathcal{G}_2$ 不是 $\mathcal{G}_1$ 的真子图. 但它是 $\mathcal{H}$ 的真子图，因此该分布不相对于 $\mathcal{H}$ 满足因果极小性. 一般来说，因果极小性比忠实性弱.

命题 6.35（忠实性蕴含因果极小性） 如果 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 既忠实又满足 Markov 性，则满足因果极小性.

证明： 论证如下：如果 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 的真子图 $\widetilde{\mathcal{G}}$ 满足 Markov 性，那么存在两个节点，它们在 $\mathcal{G}$ 中直接连接而在 $\widetilde{\mathcal{G}}$ 中没有直接连接. 因此，它们可以在 $\widetilde{\mathcal{G}}$ 中被 d 分离，但不能在 $\mathcal{G}$ 中被 d 分离（见问题 6.62）. Markov 条件蕴含 $P_{\mathbf{X}}$ 中相应的条件独立性陈述，因此 $P_{\mathbf{X}}$ 不可能忠实于 $\mathcal{G}$. □

以下表述等价于因果极小性，希望有助于理解这一条件：分布相对于 $\mathcal{G}$ 极小，当且仅当不存在这样的节点——给定其余父节点时，它条件独立于其任何一个父节点. 在某种意义上，所有父节点都是 “活动的”.

命题 6.36（因果极小性的等价表述） 考虑随机向量 $\mathbf{X} = (X_1, \ldots, X_d)$，并假设联合分布相对于乘积测度有密度. 假设 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 满足 Markov 性. 那么 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 满足因果极小性，当且仅当对所有 X_j 和所有 $Y \in \mathbf{PA}_j^{\mathcal{G}}$，都有

$$X_j \not\perp\!\!\!\perp Y \mid \mathbf{PA}_j^{\mathcal{G}} \setminus \{Y\}.$$

证明见附录 C.6.

我们已经看到，忠实性是将条件独立性陈述与因果语义联系起来的强假设，而因果极小性弱得多. 例如假设给定一个因果图模型，其中因果极小性被违背. 那么按照命题 6.36 的意义，有一条边是 “不活动的”. 删除此边后，两个模型不一定在定义 6.47 的意义下反事实等价或干预等价. 不过，如果所有密度都严格为正（或者我们只允许对 X_k 的干预支撑在 X_k 的支撑的子集内），它们是干预等价的；见问题 6.58. 此时，因果极小性可以解释为避免干预模型描述冗余的约定. 在大多数模型类中，不满足因果极小性就无法从观测数据获得可识别性. 例如，如果允许 f 只在 X 的支撑之外不同于 c，则无法区分 $Y := f(X) + N_Y$ 和 $Y := c + N_Y$；另见注 6.6 和命题 6.49.

[12] 更准确地说，它不满足三角忠实性 [Zhang 和 Spirtes, 2008].

6.6 通过协变量调整计算干预分布

本节的协变量调整（covariate adjustment）将利用一个多少有些平凡、但非常有力的不变性陈述. 给定 SCM $\mathfrak{C}$，记 $pa(j) := \mathbf{PA}_j^{\mathcal{G}}$，则对于任何通过干预某些 X_k 而非 X_j 从 $\mathfrak{C}$ 构造的 SCM $\widetilde{\mathfrak{C}}$，有

$$p^{\widetilde{\mathfrak{C}}}(x_j \mid x_{pa(j)}) = p^{\mathfrak{C}}(x_j \mid x_{pa(j)}). \tag{6.7}$$

式 (6.7) 表明因果关系在干预下是自主的；因此这一性质有时称为“自主性”. 如果我们干预某个变量，其他机制保持不变（见图 2.2 左框）.

由式 (6.7) 可以推导出一个公式，它有三个名称：截断因子分解 [Pearl, 1993]、G 计算公式 [Robins, 1986] 及操作定理 [Spirtes 等, 2000]. 其重要性在于：即使从未见过某个干预分布的数据，也可以计算关于该分布的陈述.

考虑具有结构赋值

$$X_j := f_j(\mathbf{X}_{pa(j)}, N_j), \qquad j = 1, \dots, d,$$

和密度 $p^{\mathfrak{C}}$ 的 SCM $\mathfrak{C}$. 由 Markov 性可得[13]

$$p^{\mathfrak{C}}(x_1, \dots, x_d) = \prod_{j=1}^{d} p^{\mathfrak{C}}(x_j \mid x_{pa(j)}).$$

现在考虑从 $\mathfrak{C}$ 经 $do(X_k := \widetilde{N}_k)$ 得到的 SCM $\widetilde{\mathfrak{C}}$，其中 $\widetilde{N}_k$ 容许密度 $\widetilde{p}$. 再次由 Markov 假设可得

$$\begin{aligned} p^{\mathfrak{C};do(X_k:=\widetilde{N}_k)}(x_1, \dots, x_d) &= \prod_{j \neq k} p^{\mathfrak{C};do(X_k:=\widetilde{N}_k)}(x_j \mid x_{pa(j)}) \cdot p^{\mathfrak{C};do(X_k:=\widetilde{N}_k)}(x_k) \\ &= \prod_{j \neq k} p^{\mathfrak{C}}(x_j \mid x_{pa(j)})\, \widetilde{p}(x_k). \end{aligned} \tag{6.8}$$

最后一步利用了强有力的不变性 (6.7). 式 (6.8) 使我们能够从观测量（右侧）计算干预陈述（左侧）. 一个特例是

$$p^{\mathfrak{C};do(X_k:=a)}(x_1, \dots, x_d) = \begin{cases} \prod_{j \neq k} p^{\mathfrak{C}}(x_j \mid x_{pa(j)}), & x_k = a, \\ 0, & \text{其他情况}. \end{cases} \tag{6.9}$$

通常，以 $do(\cdot)$ 表示的干预与条件化是不同操作（见例 6.10 后的讨论）. 现在可以说明，对于没有父变量的变量，这些操作变得相同. 不失一般性，设 X_1 是这样的源节点. 则

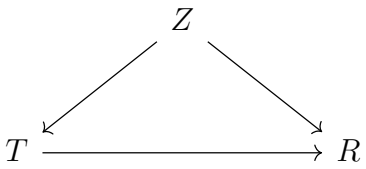
$$\begin{aligned} p^{\mathfrak{C}}(x_2, \dots, x_d \mid x_1 = a) &= \frac{p(x_1 = a) \prod_{j=2}^{d} p^{\mathfrak{C}}(x_j \mid x_{pa(j)})}{p(x_1 = a)} \\ &= p^{\mathfrak{C};do(X_1:=a)}(x_2, \dots, x_d). \end{aligned} \tag{6.10}$$

[13] 注意，即使对于满足 $p^{\mathfrak{C}}(x_{pa(j)}) = 0$ 的 $x_{pa(j)}$，条件分布 $p^{\mathfrak{C}}(x_j \mid x_{pa(j)})$ 也可以定义.

式 (6.8) 和 (6.9) 用途广泛，但有时使用起来稍显繁琐. 现在学习一些实用替代方法. 为此先回顾例 6.16（肾结石），随后将其推广.

译注：本节源书对原子干预仍用密度记号. 连续变量上的原子干预通常须用 *Dirac* 点质量或相应测度表示；零概率条件值还涉及条件分布版本，不能把字面密度式视为已完成测度论论证.

例 6.37（肾结石，续） 假设真实底层 SCM 容许图



其中 Z 是结石大小，T 是治疗，R 是康复情况（均为二元变量）. 可以看到，康复受到治疗和结石大小的影响；治疗本身也依赖结石大小. 很大比例的困难病例被分配给治疗 A. 再考虑分别将 T 的结构赋值替换为 $T := A$ 与 $T := B$ 后得到的两个 SCM $\mathfrak{C}_A, \mathfrak{C}_B$，将其对应的结果概率分布记为 $P^{\mathfrak{C}_A}, P^{\mathfrak{C}_B}$. 如果我们被诊断出患有肾结石但不知道大小，就应根据以下两者的比较选择治疗：

$$\mathbb{E}^{\mathfrak{C}_A} R = P^{\mathfrak{C}_A}(R = 1) = P^{\mathfrak{C};do(T:=A)}(R = 1)$$

以及

$$\mathbb{E}^{\mathfrak{C}_B} R = P^{\mathfrak{C}_B}(R = 1) = P^{\mathfrak{C};do(T:=B)}(R = 1).$$

给定从 $\mathfrak{C}$ 观测到的数据，如何估计这些量？考虑以下计算：

$$\begin{aligned} P^{\mathfrak{C}_A}(R = 1) &= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R = 1, T = A, Z = z) \\ &= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R = 1 \mid T = A, Z = z) P^{\mathfrak{C}_A}(T = A, Z = z) \\ &= \sum_{z=0}^{1} P^{\mathfrak{C}_A}(R = 1 \mid T = A, Z = z) P^{\mathfrak{C}_A}(Z = z) \\ &\overset{(6.7)}{=} \sum_{z=0}^{1} P^{\mathfrak{C}}(R = 1 \mid T = A, Z = z) P^{\mathfrak{C}}(Z = z). \end{aligned} \tag{6.11}$$

最后一步包含了关键思想：我们再次利用不变性 (6.7). 从表 6.1 中的经验数据可以估计

$$P^{\mathfrak{C}_A}(R = 1) \approx 0.93 \cdot \frac{357}{700} + 0.73 \cdot \frac{343}{700} = 0.832.$$

类似地，得到

$$P^{\mathfrak{C}_B}(R = 1) \approx 0.87 \cdot \frac{357}{700} + 0.69 \cdot \frac{343}{700} \approx 0.782,$$

因而得出我们更愿意选择治疗 A 的结论.（如前所述，我们忽略统计显著性问题；如果必须在 A, B 之间作决定，这似乎合理.）对于二元治疗，量

$$P^{\mathfrak{C}_A}(R=1) - P^{\mathfrak{C}_B}(R=1) \approx 0.832 - 0.782 \tag{6.12}$$

有时称为平均因果效应（ACE）. 重要的是认识到，这不同于简单条件化：

$$P^{\mathfrak{C}}(R=1 \mid T=A) - P^{\mathfrak{C}}(R=1 \mid T=B) = 0.78 - 0.83,$$

在本例中它甚至与 ACE 符号相反.

这个三节点例子很好地凸显了干预与条件化的区别. 用密度表示为

$$p^{\mathfrak{C};do(T:=t)}(r) = \sum_z p^{\mathfrak{C}}(r \mid z,t)p^{\mathfrak{C}}(z) \neq \sum_z p^{\mathfrak{C}}(r \mid z,t)p^{\mathfrak{C}}(z \mid t) = p^{\mathfrak{C}}(r \mid t).$$

式 (6.11) 称为对变量 Z 的 “调整”. 这是实践中常用的重要概念，将在定义 6.38 中形式化. 它再次使我们能够从观测量计算干预陈述. 注意，调整公式 (6.11) 的推导有时基于截断因子分解 (6.9)；但命题 6.41 将表明，使用不变性的这一替代计算可以很好地推广到更复杂的情形.

定义 6.38（有效调整集） 考虑节点集合为 V 的 SCM $\mathfrak{C}$，设 $Y \notin \mathbf{PA}_X$. 否则有 $p^{\mathfrak{C};do(X:=x)}(y) = p^{\mathfrak{C}}(y)$. 如果

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_{\mathbf{z}} p^{\mathfrak{C}}(y \mid x, \mathbf{z})p^{\mathfrak{C}}(\mathbf{z}), \tag{6.13}$$

则称集合 $\mathbf{Z} \subseteq V \setminus \{X, Y\}$ 是有序对 (X, Y) 的有效调整集. 这里求和（也可以是积分）遍及 $\mathbf{Z}$ 的值域，即 $\mathbf{Z}$ 可取得的所有值 $\mathbf{z}$.

在例 6.37 中，$\mathbf{Z} = \{Z\}$ 是 (T, R) 的有效调整集. 为计算平均因果效应，需要对 Z 调整；我们已经看到简单条件化会导致错误结论. 换言之，空集不是有效调整集. 在此情况下，我们称从 T 到 R 的因果效应受到混杂.

定义 6.39（混杂） 考虑节点集合为 V 的 SCM $\mathfrak{C}$，其中 $X, Y \in V$ 且存在从 X 到 Y 的有向路径. 如果

$$p^{\mathfrak{C};do(X:=x)}(y) \neq p^{\mathfrak{C}}(y \mid x), \tag{6.14}$$

则称从 X 到 Y 的因果效应受到混杂；否则称其 “未受混杂”.

有时人们认为，应当尽可能扩大调整集以减少潜在混杂因素的影响. 然而，例 6.30 中的 Berkson 悖论 [Berkson, 1946] 表明，这并不总是好主意. 它说明不是所有集合都是有效调整集，有时不将某个协变量纳入调整集反而更好. 下面尝试研究可以用哪些集合调整. 采用与例 6.37 相同的思路，对任意集合 $\mathbf{Z}$ 写出

$$\begin{aligned} p^{\mathfrak{C};do(X:=x)}(y) &= \sum_{\mathbf{z}} p^{\mathfrak{C};do(X:=x)}(y, \mathbf{z}) \\ &= \sum_{\mathbf{z}} p^{\mathfrak{C};do(X:=x)}(y \mid x, \mathbf{z})p^{\mathfrak{C};do(X:=x)}(\mathbf{z}). \end{aligned}$$

如果

$$p^{\mathfrak{C};do(X:=x)}(y \mid x, \mathbf{z}) = p^{\mathfrak{C}}(y \mid x, \mathbf{z}) \quad \text{且} \quad p^{\mathfrak{C};do(X:=x)}(\mathbf{z}) = p^{\mathfrak{C}}(\mathbf{z}), \tag{6.15}$$

则如前所述，$\mathbf{Z}$ 是有效调整集. 式 (6.15) 表示即使对 X 干预后条件分布也保持不变；我们称它们是不变的. 因此需要研究哪些条件分布在干预 $do(X := x)$ 下保持不变.

注 6.40（不变条件分布的刻画） 考虑具有结构赋值 $X_j := f_j(\mathbf{PA}_j, N_j)$ 的 SCM $\mathfrak{C}$ 和干预 $do(X_k := x_k)$. 类似于例如 Pearl [2009, 第 3.2.2 节] 的处理，现在可以构造新 SCM $\mathfrak{C}^*$：它与 $\mathfrak{C}$ 相同，但多一个变量 I 指示干预是否发生（另见第 6.3 节 “干预变量” 段）. 更准确地说，I 是 X_k 的父节点，没有其他相邻节点. 对应的结构赋值为

$$\begin{aligned} I &:= N_I, \\ X_j &:= f_j(\mathbf{PA}_j, N_j) \quad (j \neq k), \\ X_k &:= \begin{cases} f_k(\mathbf{PA}_k, N_k), & I = 0, \\ x_k, & \text{其他情况}, \end{cases} \end{aligned}$$

其中例如 N_I 服从 $P(I = 0) = P(I = 1) = 0.5$ 的 Bernoulli 分布（其他分布也可）. 因而 $I = 0$ 对应观测情景，$I = 1$ 对应干预情景. 更准确地说，利用式 (6.10)，得到

$$\begin{aligned} p^{\mathfrak{C}^*}(x_1, \ldots, x_d \mid I = 0) &= p^{\mathfrak{C}^*;do(I:=0)}(x_1, \ldots, x_d) \\ &= p^{\mathfrak{C}}(x_1, \ldots, x_d), \end{aligned}$$

类似地，

$$p^{\mathfrak{C}^*}(x_1, \ldots, x_d \mid I = 1) = p^{\mathfrak{C};do(X_k:=x_k)}(x_1, \ldots, x_d). \tag{6.16}$$

对 $\mathfrak{C}^*$ 使用 Markov 条件，对于变量 A 和变量集合 $\mathbf{B}$，可得

$$\begin{aligned} A \perp\!\!\!\perp_{\mathcal{G}^*} I \mid \mathbf{B} \Rightarrow p^{\mathfrak{C}^*}(a \mid \mathbf{b}, I = 0) &= p^{\mathfrak{C}^*}(a \mid \mathbf{b}, I = 1) \\ \Rightarrow p^{\mathfrak{C}}(a \mid \mathbf{b}) &= p^{\mathfrak{C};do(X_k:=x_k)}(a \mid \mathbf{b}). \end{aligned}$$

右侧表示，条件变量 $A \mid \mathbf{B}$ 的分布 $P_{A|\mathbf{B}}$ 在对 X_k 干预下保持不变.

现在可以继续前面的论证. 对满足

$$Y \perp\!\!\!\perp_{\mathcal{G}^*} I \mid X, \mathbf{Z} \qquad \text{且} \qquad \mathbf{Z} \perp\!\!\!\perp_{\mathcal{G}^*} I \tag{6.17}$$

的集合 $\mathbf{Z}$，式 (6.15) 成立. 下标 $\mathcal{G}^*$ 表示要求 d 分离陈述在 $\mathcal{G}^*$ 中成立. 上述推理直接蕴含以下命题的前两个陈述：

命题 6.41（有效调整集） 考虑变量 $\mathbf{X}$ 上的 SCM，其中 $X, Y \in \mathbf{X}$ 且 $Y \notin \mathbf{PA}_X$. 以下三个陈述成立：

(i) “父节点调整”：$\mathbf{Z} := \mathbf{PA}_X$ 是 (X, Y) 的有效调整集.

(ii) “后门判据”：任何 $\mathbf{Z} \subseteq \mathbf{X} \setminus \{X, Y\}$，只要它不包含 X 的后代，并且阻断所有从后门进入 X 的 X 到 Y 路径（$X \leftarrow \cdots$，见图 6.5），就是 (X, Y) 的有效调整集.

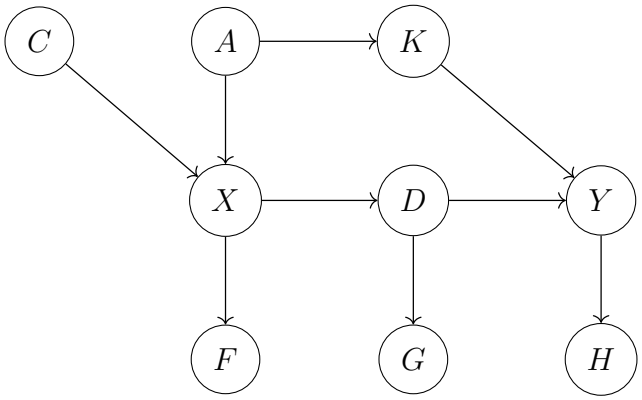


图 6.5: 只有路径 $X \leftarrow A \rightarrow K \rightarrow Y$ 是从 X 到 Y 的“后门路径”. 集合 $\mathbf{Z} = \{K\}$ 满足后门判据 (见命题 6.41(ii)); 但 $\mathbf{Z} = \{F, C, K\}$ 也是 (X, Y) 的有效调整集, 见命题 6.41(iii).

(iii) “趋向必要性”: 任何 $\mathbf{Z} \subseteq \mathbf{X} \setminus \{X, Y\}$, 只要它不包含从 X 到 Y 的有向路径上任何节点的后代 (不在从 X 到 Y 有向路径上的 X 的后代除外), 并且阻断所有从 X 到 Y 的非有向路径, 就是 (X, Y) 的有效调整集.

只有第三个陈述[Shpitser 等, 2010; Perkovic 等, 2015]需要一些解释. 从一个有效调整集 $\mathbf{Z}$ 出发, 例如由后门判据得到的集合. 此时可以向 $\mathbf{Z}$ 添加任何满足 $Z_0 \perp\!\!\!\perp Y \mid X, \mathbf{Z}$ 的节点 Z_0, 因为

$$\begin{aligned}\sum_{\mathbf{z}, z_0} p(y \mid x, \mathbf{z}, z_0) p(\mathbf{z}, z_0) &= \sum_{\mathbf{z}} p(y \mid x, \mathbf{z}) \sum_{z_0} p(\mathbf{z}, z_0) \\ &= \sum_{\mathbf{z}} p(y \mid x, \mathbf{z}) p(\mathbf{z}).\end{aligned}$$

事实上, 命题 6.41(iii) 刻画了所有有效调整集 [Shpitser 等, 2010] .

例 6.42 (线性高斯系统中的调整) 考虑变量集合 V 上的 SCM $\mathfrak{C}$, 其中 $\{X, Y\}, \mathbf{Z} \subseteq V$. 有时我们希望用单个实数概括从 X 到 Y 的因果效应, 而不是考察所有 x 的 $p^{\mathfrak{C}; do(X:=x)}(y)$. 在二元处理 X 的情形下, 我们已经见过一个例子 (见式 (6.12)) . 对连续随机变量又该如何处理? 作为初步近似, 可以先考察这个分布的期望, 再对 x 求导:

$$\frac{\partial}{\partial x} E^{\mathfrak{C}; do(X:=x)}[Y]. \tag{6.18}$$

一般而言, 这仍是 x 的函数; 但在线性高斯系统中, 它是常数. 假设 $\mathbf{Z}$ 是 (X, Y) 的有效调整集. 若 V 服从高斯分布, 则条件分布 $Y \mid X = x, \mathbf{Z} = \mathbf{z}$ 也为高斯分布, 其均值为

$$E[Y \mid X = x, \mathbf{Z} = \mathbf{z}] = ax + \mathbf{b}^t \mathbf{z} \tag{6.19}$$

其中 a 和 $\mathbf{b}$ 为某些系数. 由式 (6.13) 可得 (见问题 6.63)

$$\frac{\partial}{\partial x} E^{\mathfrak{C}; do(X:=x)}[Y] = a. \tag{6.20}$$

有两种方法得到式 (6.19) 中的 a. 一是使用路径系数法: 如果从 X 到 Y 恰有一条有向路径, 则 a 等于路径系数的乘积; 如果没有有向路径, 则 $a = 0$; 如果有多条路径, 可

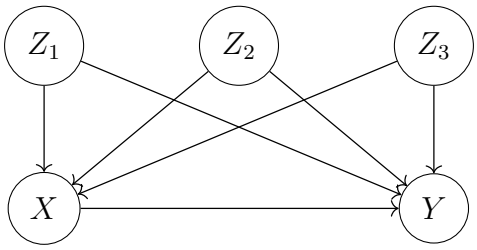
用 Wright 公式 [Wright, 1934] 计算 a. 二是直接计算条件均值 (6.19). 若给出的不是联合分布，而是其一个样本，可以将 Y 对 X 和 $\mathbf{Z}$ 回归，然后读出 X 的回归系数，以估计式 (6.20)（另见代码片段 6.43）.

代码片段 6.43 以下代码从具有图 6.5 所示结构的 SCM 生成大小为 $n = 100$ 的独立同分布样本（系数见代码）. 由于已知底层 SCM，式 (6.20) 的真实值可通过相乘路径 $X \to D \to Y$ 的系数得到；在此例中为 $(-2)\cdot(-1) = 2$（见代码第 8、10 行）. 现在假设结构赋值的确切形式，即系数集合未知，但给出了数据样本及 SCM 的图结构（见图 6.5）. 可以将 Y 对 X 和调整集 $\mathbf{Z}$ 回归，估计式 (6.20). 若 $\mathbf{Z}$ 是有效调整集，得到的估计量无偏. 代码中 $\mathbf{Z} = \varnothing$ 得到有偏估计量（见第 15 行）；只有 $\mathbf{Z} = \{K\}$ 和 $\mathbf{Z} = \{F, C, K\}$ 是有效调整集（分别见第 19、23 行）.

```
# generate a sample from the distribution entailed by the SCM
set.seed(1); n <- 100
C <- rnorm(n)
A <- 0.8*rnorm(n)
K <- A + 0.1*rnorm(n)
X <- C - 2*A + 0.2*rnorm(n)
F <- 3*X + 0.8*rnorm(n)
D <- -2*X + 0.5*rnorm(n)
G <- D + 0.5*rnorm(n)
Y <- 2*K - D + 0.2*rnorm(n)
H <- 0.5*Y + 0.1*rnorm(n)
#
lm(Y~X)$coefficients
# (Intercept)---------X
# 0.09724282 1.27941073
#
lm(Y~X+K)$coefficients
# (Intercept)---------X----------K
# 0.01428974 2.07038809 2.16964827
#
lm(Y~X+F+C+K)$coefficients
# (Intercept)---------X----------F-----------C----------K
# 0.01687018 1.90495456 0.05901385 -0.02260164 2.18276488
```

下面简述倾向得分匹配 [Rosenbaum 与 Rubin, 1983]. 以下注重复了 Pearl [2009, 第 11.3.5 节] 的论证.

注 6.44（倾向得分匹配） 考虑变量 $\mathbf{X} = (X, Y, \mathbf{Z})$ 上的 SCM，其中 $\mathbf{Z} = (Z_1, Z_2, Z_3)$，图为



例如利用父节点调整（见命题 6.41）可知，集合 $\{Z_1, Z_2, Z_3\}$ 是有效调整集，即

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_{z_1,z_2,z_3} p^{\mathfrak{C}}(y \mid x, z_1, z_2, z_3) p^{\mathfrak{C}}(z_1, z_2, z_3). \tag{6.21}$$

但有时 X 的值并不“直接”依赖于 $\mathbf{Z}$，而仅通过一个实值倾向得分 $L := L(\mathbf{Z}) = L(Z_1, Z_2, Z_3)$ 依赖于它. 这意味着 $X \perp\!\!\!\perp \mathbf{Z} \mid L(\mathbf{Z})$；更形式化地，对所有 $\mathbf{z}, x$ 和 $\ell = L(\mathbf{z})$，有 $p(\mathbf{z} \mid \ell, x) = p(\mathbf{z} \mid \ell)$. 若二元选择 X 表示接受或不接受处理，例如可取 $L(\mathbf{z}) = p(x = 1 \mid \mathbf{Z} = \mathbf{z})$. 于是由式 (6.21) 可得

$$\begin{aligned} p^{\mathfrak{C};do(X:=x)}(y) &= \sum_{\mathbf{z}} p^{\mathfrak{C}}(y \mid x, \mathbf{z}) p^{\mathfrak{C}}(\mathbf{z}) = \sum_{\mathbf{z}} \sum_{\ell} p^{\mathfrak{C}}(y \mid x, \mathbf{z}) p^{\mathfrak{C}}(\ell) p^{\mathfrak{C}}(\mathbf{z} \mid \ell) \\ &= \sum_{\mathbf{z}} \sum_{\ell} p^{\mathfrak{C}}(y \mid \ell, x, \mathbf{z}) p^{\mathfrak{C}}(\ell) p^{\mathfrak{C}}(\mathbf{z} \mid \ell, x) \\ &= \sum_{\ell} p^{\mathfrak{C}}(y \mid \ell, x) p^{\mathfrak{C}}(\ell). \end{aligned} \tag{6.22}$$

在总体情形下，式 (6.21) 和 (6.22) 对干预分布的计算均正确. 不过，对有限数据，后者可能给出更好的估计：虽然需要估计函数 L，所得条件分布 $p^{\mathfrak{C}}(y \mid x, \ell)$ 的维数可能低于 $p^{\mathfrak{C}}(y \mid x, \mathbf{z})$. 实践中常匹配 ℓ 值“相近”的实现值来计算式 (6.22). 重要的实践细节包括估计函数 L 和匹配步骤. 这一思路适用于任意数量的协变量.

从这个意义上说，倾向得分匹配可以是提高统计性能的有用技巧；它与总体层面的考虑无关.

6.7 *do* 演算

再次考虑变量集合 V 上的 SCM. 有时可以通过调整公式 (6.13) 以外的方法计算干预分布 $p^{\mathfrak{C};do(X:=x)}$. 因此，如果干预分布 $p^{\mathfrak{C};do(X:=x)}(y)$ 可由观测分布和图结构算出，就称其可识别. 例如，若存在 (X, Y) 的有效调整集，则 $p^{\mathfrak{C};do(X:=x)}(y)$ 必然可识别. Pearl [2009，定理 3.4.1] 提出了由三条规则组成的所谓 *do* 演算. 给定图 $\mathcal{G}$ 和互不相交的子集 $\mathbf{X}, \mathbf{Y}, \mathbf{Z}, \mathbf{W}$，有：

1. “插入 / 删除观测”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y} \mid \mathbf{z}, \mathbf{w}) = p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y} \mid \mathbf{w})$$

条件是在删去所有进入 $\mathbf{X}$ 的边所得图中，$\mathbf{Y}$ 与 $\mathbf{Z}$ 被 $\mathbf{X}, \mathbf{W}$ d 分离.

2. “交换行动与观测”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x},\mathbf{Z}:=\mathbf{z})}(\mathbf{y} \mid \mathbf{w}) = p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y} \mid \mathbf{z}, \mathbf{w})$$

条件是在删去所有进入 $\mathbf{X}$ 和离开 $\mathbf{Z}$ 的边所得图中，$\mathbf{Y}$ 与 $\mathbf{Z}$ 被 $\mathbf{X}, \mathbf{W}$ d 分离.

3. “插入 / 删除行动”：

$$p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x},\mathbf{Z}:=\mathbf{z})}(\mathbf{y}\mid\mathbf{w})=p^{\mathfrak{C};do(\mathbf{X}:=\mathbf{x})}(\mathbf{y}\mid\mathbf{w})$$

条件是在删去所有进入 $\mathbf{X}$ 和 $\mathbf{Z}(\mathbf{W})$ 的边所得图中，$\mathbf{Y}$ 与 $\mathbf{Z}$ 被 $\mathbf{X},\mathbf{W}$ d 分离. 这里 $\mathbf{Z}(\mathbf{W})$ 是 $\mathbf{Z}$ 中在删去所有进入 $\mathbf{X}$ 的边所得图里不是 $\mathbf{W}$ 中任何节点祖先的节点子集.

定理 6.45（*do* 演算） 以下陈述成立：

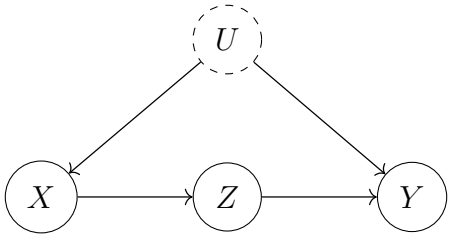
(i) 这些规则是完备的：所有可识别的干预分布均可通过迭代应用这三条规则计算 [Huang 与 Valtorta, 2006；Shpitser 与 Pearl, 2006]．

(ii) 事实上，Tian [2002] 提出了一种算法，保证能找到所有可识别的干预分布 [Huang 与 Valtorta, 2006；Shpitser 与 Pearl, 2006]．

(iii) 存在一个基于所谓 hedge 的干预分布可识别性的图形充要判据 [Shpitser 与 Pearl, 2006，推论 3；另见 Huang 与 Valtorta, 2006]．

do 演算的一个推论是前门调整（见问题 6.65）．

例 6.46（前门调整） 设 $\mathfrak{C}$ 是对应于下图的 SCM：



如果没有观测到 U，就无法应用后门判据；事实上不存在有效调整集. 但只要 $p^{\mathfrak{C}}(x,z)>0$，*do* 演算仍给出

$$p^{\mathfrak{C};do(X:=x)}(y)=\sum_{z}p^{\mathfrak{C}}(z\mid x)\sum_{\tilde{x}}p^{\mathfrak{C}}(y\mid\tilde{x},z)p^{\mathfrak{C}}(\tilde{x}). \tag{6.23}$$

这里在观测 X 和 Y 之外再观测 Z 便揭示出因果信息，这清楚说明也可以通过观测承载从 X 到 Y 的“信号”的“通道”（此处为 Z）来探索因果关系.

Bareinboim 与 Pearl [2014] 考察了可迁移性问题. 他们同样关注干预分布，但允许纳入从其他 SCM 获得的知识（即观测分布和干预分布）；这些 SCM 的某些结构赋值与目标 SCM 相同，另一些则不同.

6.8 因果模型的等价性与可证伪性

到目前为止，SCM 都是数学对象. 为将它们与现实联系起来，我们把它们视为数据生成过程的模型. 不过，这类模型可能很复杂. 我们现在不仅可以对联合分布建模（例如，可以用 Poisson 过程模拟物理过程），还可以同时对系统的观测状态及其受到扰动时的状态建模. 我们已经看到，甚至可以把 SCM 看作反事实陈述的模型.

更形式化地说，考虑随机变量向量 $\mathbf{X} = (X_1, \dots, X_d)$. $\mathbf{X}$ 的概率模型预测一个观测分布 $P_{\mathbf{X}}$. 如果模型还预测某些变量 X_j 被设为（独立）变量 $\widetilde{N}_j$ 时的干预分布，我们称其为干预模型. 最后，反事实模型还预测反事实陈述的结果. 例如，传统机器学习方法建立概率模型；因果图模型（定义 6.32）可以用作干预模型，SCM 则可以用作反事实模型. 如果两个模型的相应预测一致，就称它们等价［类似构造见 Bongers 等, 2016］.

定义 6.47（因果模型的等价性） 若两个模型蕴含相同的观测分布，则称它们概率等价；若蕴含相同的观测和干预分布，则称它们干预等价；若蕴含相同的观测、干预和反事实分布，则称它们反事实等价.

显然，例如干预等价的概念仅适用于干预模型和反事实模型. 命题 7.1 蕴含，对每个概率模型都存在与其观测等价的 SCM.

如果 $\mathbf{X}$ 具有严格正密度，命题 6.48 表明，可以将考察限制在单节点干预，即将变量 X_j 设为分布具有完全支撑的变量 $\widetilde{N}_j$. 如果两个模型在这类干预上一致，那么它们在所有其他干预上也一致. 这样做的理由是单节点干预对应于随机实验的标准形式.

对给定的数据生成过程，如果概率模型或干预模型所对应的分布与从该过程观测到的数据不一致，我们便可以证伪该模型. 也就是说，如果一个干预模型正确预测观测分布，却无法预测随机实验中发生的情况，该模型仍被视为已证伪. 这个概念假设人们对随机实验应如何进行达成共识. 当不清楚在现实中如何对相关变量进行随机化（或实施干预）时，写出 SCM 应当谨慎. 可证伪性还需要（统计）显著性的概念，本书不予讨论. 这里不包括反事实模型，因为它们通常难以证伪；我们可以根据它们对观测分布和干预分布的推论来证伪它们（见 Shpitser 与 Pearl [2008a] 及其中参考文献）. 在某些特定实验设置中，还可构造可证伪的反事实陈述（见例 3.4）. 然而，例 6.19 给出了两个蕴含相同观测分布和干预分布、但蕴含不同反事实陈述的 SCM.

上述将干预限制在一个子类（将单个变量设为噪声变量）的做法具有实践目的. 为检验模型的有效性，需要将随机实验的结果与模型预测比较；对于更复杂的干预，相应的现实实验似乎更难实施. 以下命题指出，这种限制不失一般性：如果因果模型对所有单节点干预一致，则它们干预等价. 证明见附录 C.7.

命题 6.48（干预等价） 假设两个 SCM（或因果图模型）$\mathfrak{C}_1, \mathfrak{C}_2$ 诱导严格为正的连续条件密度 $p(x_j \mid x_{pa(j)})$，其中 $pa(j) := \mathbf{PA}_{X_j}$，且满足因果极小性. 进一步假设它们蕴含相同的干预分布，其中某个变量 X_j 被设为具有完全支撑的变量 $\widetilde{N}_j$：

$$P_{\mathbf{X}}^{\mathfrak{C}_1;do(X_j:=\widetilde{N}_j)} = P_{\mathbf{X}}^{\mathfrak{C}_2;do(X_j:=\widetilde{N}_j)} \qquad \forall j \ \forall \widetilde{N}_j (\text{具有完全支撑}) .$$

那么 $\mathfrak{C}_1$ 和 $\mathfrak{C}_2$ 干预等价，即它们对任何可能的干预均一致，包括原子干预或改变父节点集合的干预（不产生有向环）.

如果密度并非严格为正，情况未必如此. 此时可能必须考虑对多个节点同时干预（例如双基因敲除实验）；见问题 6.59.

此外，现在可以说明 SCM 的结构极小性概念（见注 6.6）. 我们曾指出，如果 SCM 的一个结构赋值中的函数不依赖于某个输入，可以选择更稀疏的表示. 以下命题形式化了这些表示在何种意义下等价.

命题 6.49（反事实等价） 考虑具有相同噪声分布 $P_{\mathbf{N}}$ 的两个 SCM $\mathfrak{C}$ 和 $\mathfrak{C}^*$，它们仅

在第 k 个结构赋值上不同：

$$f_k(pa_k, n_k) = f_k^*(pa_k^*, n_k), \qquad \forall pa_k,\ \forall n_k \text{ 满足} p(n_k) > 0, \tag{6.24}$$

其中 $\mathbf{PA}_k^* \subsetneq \mathbf{PA}_k$. 那么两个 SCM 反事实等价. 证明见附录 C.8.

6.9 潜在结果

现在介绍一种不基于 SCM 的因果推断方法. 这一框架通常称为潜在结果或 Rubin 因果模型，在社会科学中应用广泛. 这些思想可追溯到 Neyman [1923] 和 Fisher [1925]，他们主要讨论随机实验. Rubin [1974] 将这些思想扩展到观测研究. Rubin [2005]、Morgan 与 Winship [2007]、Imbens 与 Rubin [2015] 对该主题作了更详尽的介绍.

6.9.1 定义与例子

为说明潜在结果，我们重新考察例 3.4（眼科医生），并在这一框架下重新表述. 现在不从随机变量出发，而是从一组 n 名患者（或单位）$u = 1, \ldots, n$ 出发，其中每人可能接受治疗，也可能不接受. 我们给每名患者 u 赋予两个潜在结果：$B_u(t = 1)$ 表示该患者接受治疗（$T = 1$）时会失明（$B = 1$）还是治愈（$B = 0$）. 类似地，$B_u(t = 0)$ 表示不治疗（$T = 0$）时发生的情况. 假设两个潜在结果都是确定的. 对每名患者，治疗要么有帮助，要么没有帮助，不涉及随机性. 如果 $B_u(t = 1) = 0$ 且 $B_u(t = 0) = 1$，我们说治疗对单位 u 有正面效应.

但在实践中，我们无法检验这些条件. “因果推断的基本问题”［Holland, 1986］指出，对于每个单位 u，只能观测 $B_u(t = 1)$ 或 $B_u(t = 0)$ 之一，而不能同时观测两者. 原因是选择治疗一个人后，我们无法回到过去撤销治疗. 反过来也一样：如果决定不治疗，以后仍可以施行治疗，但这时的结果已不能解释为变量 $B_u(t = 1)$ 的结果；例如患者可能在此期间自行康复. 因此只能观测一个潜在结果，未观测量成为反事实.

表 6.2 展示了前例的一个（假设的）数据集，数据点实际上按例 3.4 所述模型采样. 为使表 6.2 的表述成立，我们通常隐含地采用稳定单位处理值假设（SUTVA）［Rubin, 2005］. 该假设指出单位之间互不干扰（例如，一个单位的潜在结果不取决于其他单位接受了哪种处理）［Cox, 1958］；此外还要求潜在结果不依赖于接受处理的方式或原因. 第 6.9.2 节将看到，当数据由 SCM 生成时（如本例），SUTVA 得到满足.

潜在结果给出治疗对个体的效应；定义单位因果效应为 $B_u(t = 1) - B_u(t = 0)$，平均因果效应为

$$CE = \frac{1}{n} \sum_{u=1}^{n} B_u(t = 1) - B_u(t = 0). \tag{6.25}$$

“因果推断的基本问题”使我们无法直接计算式 (6.25). 假设在完全随机实验中，单位 $u \in U_0 \subset \{1, \ldots, n\}$ 接受处理 $T = 0$，单位 $u \in U_1 = U_0^C$ 接受处理 $T = 1$. Neyman [1923] 表明

$$\widehat{CE} := \frac{1}{\#U_0} \sum_{u \in U_0} B_u(t = 1) - \frac{1}{\#U_1} \sum_{u \in U_1} B_u(t = 0) \tag{6.26}$$

单位 u	处理 T	潜在结果 $B_u(t=0)$	潜在结果 $B_u(t=1)$	单位因果效应
1	1	1	0	−1
2	0	1	0	−1
3	1	1	0	−1
⋮				
43	1	1	0	−1
44	0	0	1	1
45	0	1	0	−1
⋮				
119	1	1	0	−1
120	1	0	1	1
121	0	1	0	−1
⋮				
200	0	1	0	−1

表 6.2: 用潜在结果表述例 3.4. 对每位患者（或单位），只能观测两个潜在结果之一；观测信息以灰色背景表示. 治疗 T 对几乎所有患者有帮助；200 例中仅有 2 例因治疗而失明（$B=1$）. 虽然大多数情况下给予治疗（$T=1$）是好选择，但对患者 $u=120$ 恰好是错误决定. 单位因果效应为 $B_u(t=1)-B_u(t=0)$.

是式 (6.25) 的无偏估计量. 这里 $\widehat{CE}$ 中的随机性来自随机分配：它决定每个单位的两个潜在结果中观测到哪一个；结果本身视为隐藏的，而非随机的. 注意，式 (6.26) 仅含观测量，因此可以在研究完成后计算.

译注：源书将 U_0 定义为 $T=0$ 组、U_1 为 $T=1$ 组，但式 *(6.26)* 在 U_0 上求 $B_u(t=1)$、在 U_1 上求 $B_u(t=0)$，恰为相反处理下的潜在结果. 因而按字面它并非仅含观测量的可计算式；此处保留源公式和源陈述，同时明确冲突. 式 *(6.25)* 求和括号的作用域也沿原排印.

关于哪一种方法更适合实际应用，存在广泛争论［例如 Pearl, 1995；Imbens 与 Rubin, 1995；Rubin, 2004；Lauritzen, 2004］. 我们不打算积极参与这场讨论，而只提及以下三个结果：(1) 说明如何将潜在结果表示为反事实［Pearl, 2009, 第 3.6.3 节］；(2) 两个框架之间存在逻辑等价性［Galles 与 Pearl, 1998；Halpern, 2000］；(3) 简述一个近期提出的、使两种观点更加接近的框架［Richardson 与 Robins, 2013］.

6.9.2 潜在结果与 SCM 的关系

在 SCM 中，可以用反事实的语言（第 6.4 节）表示潜在结果. 在眼科医生例子中，SCM $\mathfrak{C}$ 满足 $T=N_T$ 和 $B=T\cdot N_B+(1-T)\cdot(1-N_B)$. 因而可以用 N_B, N_T 的特定值表示每位患者. 例如在表 6.2 中，患者 43 由 $N_T=1, N_B=0$ 刻画，而患者 44 满足

$N_T = 0, N_B = 1$. 于是 $t = 0$ 和 $t = 1$ 对应于对 T 的干预. 总结起来，有

$$\underbrace{B_u(t = \tilde{t})}_{\text{潜在结果}} = \underbrace{\text{SCM } \mathfrak{C} \,|_{\mathbf{N}=\mathbf{n}_u};\, do(T := \tilde{t}) \text{ 中的} B}_{\text{反事实 SCM}}, \tag{6.27}$$

其中 $\mathbf{n}_u$ 刻画单位 u [Pearl, 2009，式 (3.51)]. 由于反事实 SCM 中所有噪声项都是确定的，所蕴含的 B 的分布也是退化的，故 B 是确定的（符合要求）. 表 6.2 所示例子使用 Bernoulli 分布 $N_T \sim \text{Ber}(0.6)$、$N_B \sim \text{Ber}(0.01)$ 采样了 200 个独立同分布单位. 此时 SUTVA 成立：独立同分布假设意味着单位之间互不干扰；模块性（对 T 干预只改变 T 的结构赋值）意味着接受治疗的方式不影响结果.

下面讨论一个结果，说明式 (6.27) 中两种表示在何种意义下等价. 为此主要遵循 Pearl [2009，第 7.3.1 节] 和 Halpern [2000] 的表述. 主要论证基于以下步骤：

1. 定义性质（公理）(C0)–(C5) 和 (MP) [Halpern, 2000，第 3 节]. 例如性质 (C4) 指出

   $$T_u(t = \tilde{t}, w = \tilde{w}) = t;$$

   它公设将单位 u 的变量 T 设为 t 是“有效的”.

2. 两种表示都满足这些公理（“可靠性”）.

3. 可以证明，这些性质对反事实 SCM 是完备的：任何反事实陈述都从这些公理之一推出.

4. 可以推断，任何对反事实 SCM 成立的定理，在潜在结果世界中也成立，反之亦然.[14] 由步骤 3 还可知，任何满足这三个公理的数据集（如表 6.2）都可以用反事实 SCM 建模.[15]

译注：源性质 *(C4)* 左侧干预值为 $\tilde{t}$，右侧却写 t；此处保留不同记号，不自动合并为同一数值.

不过，两个世界的语言不同. 即使每个定理在两个框架中都成立，有些定理在某个世界里可能更“容易”证明. 类似地，定理中的每个假设都对底层数据生成过程施加限制；取决于具体应用，某种表述可能使这些限制更容易评估. 对平均因果效应为零而个体因果效应非零的情形，使用潜在结果似乎更容易. 另一方面，SCM 的图形表示可能有助于利用有关随机变量之间因果关系的假设.

Richardson 与 Robins [2013] 提议使用单世界干预图. 这些图允许将变量设为特定值，从而构造反事实变量对应的图形. 利用修改后的图，可以读出同时涉及事实变量和反事实变量的条件独立性陈述. 因此，这些图可作为有用工具，将图形假设转化为潜在结果分析中常用的反事实陈述.

[14] 严格来说，“反之亦然”要求潜在结果框架不作超出上述公理的假设.

[15] 如果没有任何 SCM 能生成该数据集，就意味着 SCM 的反事实满足另一条并非由这三个公理蕴含的性质，即无法生成该数据集.

6.10 联系单个对象的广义结构因果模型

此前我们研究了随机变量 $X_1, \dots, X_d$ 之间的因果关系，只关注数据是从 $P_{\mathbf{X}}$ 独立同分布抽取的观测值的情形. 现在考虑因果 DAG 的节点集合 $\mathbf{v} = \{x_1, \dots, x_d\}$，其中节点由任意数学对象 $x_1, \dots, x_d$ 构成，以形式化观测的概念. 例如，观察到不同作者所写文本 $x_1, \dots, x_d$ 之间的相似性后，人们可能关心谁受到谁影响这一意义上的因果关系. 遵循 Steudel 等 [2010]，现在说明在给定适当信息概念时，底层 DAG 在何种意义下也蕴含条件独立性陈述，而不涉及统计采样. 为此假设给定信息函数

$$R : 2^{\mathbf{v}} \to \mathbb{R}_0^+,$$

它是单调的：一个节点集合所含信息不超过其任何超集所含信息. 那么对任意两个节点集合 $\mathbf{x}, \mathbf{y} \subseteq \mathbf{v}$，表达式 $R(\mathbf{x}, \mathbf{y}) - R(\mathbf{y})$ 非负，可以解释为给定 $\mathbf{y}$ 时 $\mathbf{x}$ 的条件信息. 此外假设 R 使得对任意三个两两不交的节点集合 $\mathbf{x}, \mathbf{y}, \mathbf{z}$，表达式

$$I(\mathbf{x} : \mathbf{y} \mid \mathbf{z}) := R(\mathbf{x}, \mathbf{z}) + R(\mathbf{y}, \mathbf{z}) - R(\mathbf{x}, \mathbf{y}, \mathbf{z}) - R(\mathbf{z}) \tag{6.28}$$

非负；这当且仅当 R 是次模函数时成立（见第 9.5.2 节）. 因而可以把式 (6.28) 解释为给定 $\mathbf{z}$ 时 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的广义条件互信息：$R(\mathbf{x}, \mathbf{z}) - R(\mathbf{z})$ 衡量给定 $\mathbf{z}$ 时 $\mathbf{x}$ 的信息，而 $R(\mathbf{x}, \mathbf{y}, \mathbf{z}) - R(\mathbf{y}, \mathbf{z})$ 是给定 $\mathbf{y}, \mathbf{z}$ 时 $\mathbf{x}$ 的信息. 同样，随机变量之间的条件互信息可写成 Shannon 熵之差 [Cover 与 Thomas, 1991]. 若式 (6.28) 为零，称给定 $\mathbf{z}$ 时 $\mathbf{x}$ 和 $\mathbf{y}$ 条件独立.

为定义广义 SCM，对每个观测节点 x_j 引入未观测噪声对象 n_j，并公设以下陈述.

原则 6.50（无额外信息） 节点 x_j 除其父节点 pa_j 和未观测节点 n_j 所含的信息外，不含额外信息，即

$$R(x_j, pa_j, n_j) = R(pa_j, n_j).$$

这推广了每个随机变量 X_j 由其父节点和噪声变量决定的假设. 对离散随机变量，这相当于说 $X_j, \mathbf{PA}_j, N_j$ 的 Shannon 熵等于 $\mathbf{PA}_j, N_j$ 的 Shannon 熵.

SCM 的第二个关键假设是噪声项的统计独立性，其广义形式如下.

原则 6.51（未观测对象的独立性） 未观测节点 n_j 互不包含关于彼此的信息，即

$$R(n_1, \dots, n_d) = \sum_{j=1}^{d} R(n_j).$$

Steudel 等 [2010] 证明了以下定理.

定理 6.52（广义因果 Markov 条件） 若原则 6.50 和 6.51 均成立，则对任何三个节点集合，只要 $\mathbf{x}$ 和 $\mathbf{y}$ 被 $\mathbf{z}$ d 分离，给定 $\mathbf{z}$ 时 $\mathbf{x}$ 和 $\mathbf{y}$ 条件独立.

为了将这些概念应用于文本例子，把文本看作有意义词语的集合，信息量 R 为不同词语的数量. 假设 d 篇文本 $x_1, \dots, x_d$ 之间的影响由以下简化机制给出：x_j 的作者从 x_j 的父文本中取出一些词语，再添加一些来自自己想法的词语；这些附加词语由 n_j 给出. 那么根据 n_j 的定义，原则 6.50 成立. 按原则 6.51，假设不同作者添加的词语互不相同. 给定第三篇文本时，若两篇文本仅共有已经出现在第三篇中的词语，就称它们

条件独立. 该例表明，对象的范围远比随机变量广，也可以定义合理的条件独立性概念. 为保证因果 Markov 条件对这一特定独立性概念成立，底层信息度量必须按照原则 6.50 和 6.51 的意义，适合所考虑的因果机制类.

Janzing 与 Schölkopf [2010] 使用相对于某个固定 Turing 机 T 的 Kolmogorov 复杂度 K 来量化二进制串之间的信息（见第 4.1.9 节）. 函数 K 除 $O(1)$ 项外近似次模，即误差不随所考虑字符串的大小增长. 随后 Janzing 与 Schölkopf [2010] 定义“算法因果模型”：T 根据父节点和噪声串 n_j 计算每个 x_j，从而保证原则 6.50. 每个 n_j 也可解释为根据父节点计算 x_j 的程序，即由直接原因生成 x_j 的机制. 此时原则 6.51 相当于机制的独立性（见原则 2.1）.[16] 对 $R = K$ 应用定理 6.52 得到“算法 Markov 条件”[Janzing 与 Schölkopf, 2010]：只要 $\mathbf{x}$ 和 $\mathbf{y}$ 被 $\mathbf{z}$ d 分离，给定以 $\mathbf{z}$ 作为免费背景信息的 Turing 机，知道 $\mathbf{y}$ 也不能更简短地描述 $\mathbf{x}$.

从更高层面看，这涉及因果推理中的一个深刻问题：“观测之间只有在存在因果联系时才会出现依赖”（原则 1.1 的推广）仅当依赖度量适合所考虑的观测类和潜在因果机制类时才成立. 例如，观察到一个孩子的身高在过去十年增加，同时某支股票的价值也增加，我们不会由此推断两者存在因果关系，因为增长是许多彼此没有因果联系的时间序列共有的性质. 只有当两个时间序列具有更复杂的不同增长（和 / 或下降）共同模式时，我们才会追问这种相似性的共同原因. 由于非平稳时间序列十分普遍，寻找我们相信其依赖能指示因果关系的信息度量会很有趣（若通过搜索大型数据库找到这些时间序列，还应充分考虑多重检验问题）. 从更应用的机器学习角度看，该问题促使我们构造适当特征，使特征空间中的相似性指示因果关系.

6.11 条件分布的算法独立性

第 6.10 节表明，因果结构不仅蕴含统计（条件）独立性，也蕴含关于其他非统计信息度量的独立性. 我们还看到，Markov 条件也可对算法信息表述. 算法 Markov 条件最基本的推论是算法依赖的 Reichenbach 原则：两个对象只有在具有共同原因或其中一个影响另一个时才可能算法依赖 [Janzing 与 Schölkopf, 2010]，因为否则它们被空集 d 分离，因而独立. 类似地，彼此没有因果关系的 d 个对象 $x_1, \dots, x_d$ 联合算法独立，即

$$K(x_1, \dots, x_d) \stackrel{+}{=} \sum_{j=1}^{d} K(x_j). \tag{6.29}$$

也可以将左右两侧之差称为多元信息（类比统计信息论中对应的术语），并将联合独立性写为

$$I(x_1, x_2, \dots, x_d) \stackrel{+}{=} 0. \tag{6.30}$$

联合独立性也蕴含任意子集的独立性. 例如，如果 x_1, x_2 的联合描述比它们分别描述更短，那么 $x_1, \dots, x_d$ 的联合描述自然比所有 x_j 的分别描述更短，因此式 (6.30) 蕴含 $I(x_1 : x_2) \stackrel{+}{=} 0$.

[16] 因此，图 2.2 的第二、第三个分支可视为一致：字符串 n_j 编码机制（即在 Turing 机上运行的程序），同时也是统计情形下噪声项的对应物.

如果现在假设因果图模型中的条件分布[17] $P_{X_j|\mathbf{PA}_j}$ 由“自然独立选取”，便可推断它们联合算法独立［Janzing 与 Schölkopf, 2010；Lemeire 与 Janzing, 2013］，并表述原则 4.13 的多变量版本.

原则 6.53（条件分布的算法独立性，AIC） 如定义 6.21(iii) 所述，因果 Bayesian 网络中 Markov 核所描述的因果条件分布算法独立，即

$$I(P_{X_1|\mathbf{PA}_1}, P_{X_2|\mathbf{PA}_2}, \ldots, P_{X_d|\mathbf{PA}_d}) \stackrel{+}{=} 0, \tag{6.31}$$

或等价地，

$$K(P_{X_1,\ldots,X_d}) \stackrel{+}{=} \sum_{j=1}^{d} K(P_{X_j|\mathbf{PA}_j}). \tag{6.32}$$

注意，原则 6.53 不应与第 6.10 节讨论的算法 Markov 条件混淆. 后者涉及 n 个单独对象之间的因果关系，不涉及统计采样；前者仍假设 n 个随机变量处于传统独立同分布情形，只是附加了一条推断原则.

与双变量情形一样，式 (6.31) 和 (6.32) 的等价性直接成立，因为描述联合分布等价于描述所有因果 Markov 核. 换言之，AIC 指出联合分布的最短描述由各因果 Markov 核的分别描述给出.

因果忠实性与 AIC 在精神上相关，往往得出类似结论. 为讨论异同，我们重新考察例 6.34. 由于参数 a 描述 $P_{Y|X}$，参数 (b,c) 描述条件分布 $P_{Z|X,Y}$，有

$$I(P_{Y|X} : P_{Z|X,Y}) \stackrel{+}{\geq} I(a : (b,c)). \tag{6.33}$$

这是因为将注意力限制在两个对象的某些“方面”不会增加它们之间的算法互信息；例如见 Janzing 与 Schölkopf [2010，引理 6]. 当线性模型的结构系数满足

$$a \cdot b + c = 0 \tag{6.34}$$

时，出现“非一般性”独立 $X \perp\!\!\!\perp Z$. 此时 $K(a \mid b,c) \stackrel{+}{=} 0$，因为可以用长度为 $O(1)$ 的程序由 b,c 计算 a. 因而

$$I(a : (b,c)) \stackrel{+}{=} K(a) - K(a \mid (b,c)^*) \stackrel{+}{=} K(a).$$

我们得出，只要 $K(a)$ 显著大于 0，AIC 就被违背. 对一般实数 a，$K(a)$ 随所需（相对）精度按对数增长. 此时 AIC 排除相应的因果 DAG，因为式 (6.34) 被认为是一个不太可能的巧合.

需要解释“只要 $K(a)$ 显著大于 0”，因为这涉及 AIC 与忠实性的概念差异. 例如假设 $b = c$ 且 $a = -1$. 这时式 (6.34) 成立，但知道 b,c 不会缩短 a 的描述，因为 $K(a)$ 已经可以忽略. 因此，尽管式 (6.34) 似乎表明参数经过精细调节，AIC 仍未被违背. 遵循 Lemeire 与 Janzing [2013]，我们说明为什么认为不排除这类调节是 AIC 的优点，而非缺陷. 思路是，自然界中的结构系数 ± 1（在某个给定精度内）比 2.36724… 等更“一般”

[17] 如前所述，我们用 $P_{Y|X}$ 简记条件分布族 $(P_{Y|X=x})_x$.

的值常见得多. 例如，花费金额 S 会使可用金额 A 减少 S，因而 S 与 A 的因果关系由结构系数 -1 描述.[18] AIC 和我们的论证隐含地基于一种先验：描述长度短的值更可能出现（与 Solomonoff 归纳推断理论一致 [Solomonoff, 1964]）.

AIC 的另一个特点是，它也排除不同路径的近乎抵消. 例如假设 a 非常接近 $-c/b$. 为估计此时的 $I(a:(b,c))$，注意到

$$I(a:(b,c)) \overset{+}{\geq} I(a:(c/b)),$$

并使用以下思路：两个彼此接近的整数 n, m 的算法互信息通常约为 $\log[n/|m-n|]$，因为知道 m 后描述 n 约需 $\log|n-m|$ 比特，否则约需 $\log n$ 比特. 经任意精细离散化后，可以用整数表示 a 和 c/b，并以 $\log[a/(a+c/b)]$ 作为 $P_{Y|X}$ 与 $P_{Z|X,Y}$ 之间算法互信息的粗略估计.

6.12 习题

问题 6.54（DAG） 表 B.1 指出，三个节点共有 25 个 DAG. 为什么?

问题 6.55（多变量 SCM） 考虑以下 SCM $\mathfrak{C}$:

$$\begin{aligned} V &:= N_V, & W &:= -2V + 3Y + 5Z + N_W, \\ X &:= 2V + N_X, & Y &:= -X + N_Y, & Z &:= \alpha X + N_Z, \end{aligned}$$

其中 $N_V, N_W, N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$.

a) 画出该 SCM 对应的图.

b) 令 $\alpha = 2$，从联合分布模拟 200 个独立同分布数据点；绘出 X, W 的值，以可视化分布 $P^{\mathfrak{C}}_{X,W}$.

c) 再次令 $\alpha = 2$，从对 X 干预后的分布 $P^{\mathfrak{C};do(X:=3)}_{X,W}$ 中采样 200 个独立同分布数据点. 同样绘出样本，与 b) 的图比较.

d) 一个节点到另一节点的有向路径不一定意味着前者对后者有因果效应. 选取一个 α 的值，证明对该值 X 对 W 没有因果效应.

e) 对任意给定的 α，计算 $\frac{\partial}{\partial x} E^{\mathfrak{C};do(X:=x)}[W]$.

问题 6.56（干预） 考虑 SCM

$$X := N_X, \qquad Y := (X-4)^2 + N_Y, \qquad Z := X^2 + Y^2 + N_Z,$$

其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$. 可以对 X 或 Y 之一干预. 哪个硬干预得到最小的 Z 期望?

问题 6.57（极小性） 我们在注 6.6 中指出，因果极小性（定义 6.33）蕴含结构极小性.

[18] 此例表明结构系数简单往往是变量定义方式的结果，而非“自然”的性质. 一般而言，可以追问我们在多大程度上以产生简单因果关系的方式定义变量.

a) 确认命题 6.49 证明了这一点.

b) 给出一个满足结构极小性但违反因果极小性的 SCM 例子.

问题 6.58（因果极小性） 考虑一个因果图模型，其分布具有严格为正的连续密度，并违反因果极小性. 根据命题 6.36，此时可从图中删除一条 “不活动” 的边，得到新的因果图模型. 证明这两个模型干预等价.

问题 6.59（干预等价） 考虑形式如下的两个 SCM $\mathfrak{C}_1, \mathfrak{C}_2$：

$$X := N_X, \qquad Y := X + N_Y, \qquad Z := f_j(X, Y) + N_Z,$$

其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{U}(-1, 1)$，即 -1 到 1 之间的连续均匀分布. 选择函数 f_1, f_2，使 $\mathfrak{C}_1, \mathfrak{C}_2$ 观测等价，在所有单节点干预上一致，但对多个节点的同时干预不一致. 此题表明，如果密度并非严格为正，命题 6.48 不一定成立.

问题 6.60（有环 SCM） 证明只要方阵 B 的特征值绝对值均严格小于 1（即谱半径严格小于 1），$I - B$ 就可逆.

问题 6.61（有环 SCM） 考虑注 6.5 所述赋值 $\mathbf{X} := B\mathbf{X} + \mathbf{N}$. 证明若 B 的谱半径严格小于 1，则式 (6.3) 中定义的 $\mathbf{X}_t := B\mathbf{X}_{t-1} + \mathbf{N}$ 依分布收敛到式 (6.2) 中定义的 $\mathbf{X} := (I - B)^{-1}\mathbf{N}$.

问题 6.62（d 分离） 证明可以在 DAG $\mathcal{G}$ 中 d 分离任意两个没有边直接连接的节点. 利用此陈述证明命题 6.35.

问题 6.63（协变量调整） 假设 $\mathbf{Z}$ 是从 X 到 Y 的因果效应的有效调整集，且 $(Y, X, \mathbf{Z})$ 服从（零均值）高斯分布，满足

$$E[Y \mid X = x, \mathbf{Z} = \mathbf{z}] = ax + \mathbf{b}^t\mathbf{z}.$$

证明 $\frac{\partial}{\partial x} E^{\mathfrak{C};do(X:=x)}[Y] = a$；换言之，利用式 (6.19) 和 (6.13) 证明式 (6.20). 此结果使我们可以通过将 Y 对 $X, \mathbf{Z}$ 回归来一致估计因果效应 a.

问题 6.64（协变量调整） 利用式 (6.17) 证明命题 6.41(i)、(ii) 的父节点调整和后门判据.

问题 6.65（协变量调整） 从

$$p^{\mathfrak{C};do(X:=x)}(y) = \sum_z p^{\mathfrak{C};do(X:=x)}(y \mid z, x) p^{\mathfrak{C};do(X:=x)}(z)$$

出发，然后使用 do 演算（第 6.7 节）的规则 2 和 3，证明前门判据 (6.23).

Chapter 7

学习多变量因果模型

与第 4 章一样，我们现在转向学习因果模型的问题. 首先在第 7.1 节讨论不同假设，在这些假设下可从联合分布恢复（部分）图结构（“结构可识别性”）. 其中一些结果可由前面讨论的双变量情形推广. 与双变量情形一样，我们并没有对可识别性假设的完整刻画，未来研究可能揭示有前景的替代方案. 随后在第 7.2 节介绍从有限数据集估计图的方法与算法，例如基于独立性和基于评分的方法（“结构识别”）.

与双变量情形一样，我们再次面对 SCM 类过于灵活的问题. 给定随机变量 $\mathbf{X} = (X_1, \dots, X_d)$ 的分布 $P_{\mathbf{X}}$，不同的 SCM 能否蕴含这个分布？以下命题回答了这一问题：事实上，对许多不同图结构，通常都有诱导分布 $P_{\mathbf{X}}$ 的 SCM.[1]

命题 7.1（图结构的非唯一性） 考虑随机向量 $\mathbf{X} = (X_1, \dots, X_d)$，其分布 $P_{\mathbf{X}}$ 相对于 Lebesgue 测度有密度，且假设它相对于 $\mathcal{G}$ 满足 Markov 性. 那么存在一个图为 $\mathcal{G}$ 的 SCM $\mathfrak{C} = (\mathcal{S}, P_{\mathbf{N}})$ 蕴含分布 $P_{\mathbf{X}}$. 证明见附录 C.9.

特别地，给定任意完全 DAG，都可以找到一个对应 SCM 蕴含给定分布. 因此，与双变量情形一样，显然需要进一步假设才能得到可识别性结果. 下节讨论其中一些假设.

7.1 结构可识别性

7.1.1 忠实性

如果分布 $P_{\mathbf{X}}$ 相对于底层 DAG $\mathcal{G}^0$ 满足 Markov 性和忠实性，那么图 $\mathcal{G}^0$ 中的 d 分离陈述与分布中相应的条件独立性陈述一一对应. 因此可以排除 $\mathcal{G}^0$ 的正确 Markov 等价类之外的所有图，因为它们施加的 d 分离集合不等于 $P_{\mathbf{X}}$ 中的条件独立性集合. 由于 Markov 条件和忠实性仅约束联合分布中的条件独立性，也显然不能区分两个 Markov 等价的图，即蕴含完全相同条件独立性集合的两个图（例如见图 6.4）. 总之，在 Markov 条件和忠实性下，由 CPDAG($\mathcal{G}^0$) 表示的 $\mathcal{G}^0$ 的 Markov 等价类可从 $P_{\mathbf{X}}$ 识别 [例如 Spirtes 等, 2000].

引理 7.2（Markov 等价类的可识别性） 假设 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}^0$ 满足 Markov 性和忠实性. 那么对每个 $\mathcal{G} \in \text{CPDAG}(\mathcal{G}^0)$，都能找到一个蕴含分布 $P_{\mathbf{X}}$ 的 SCM. 此外，不存在 $\mathcal{G} \notin \text{CPDAG}(\mathcal{G}^0)$ 使 $P_{\mathbf{X}}$ 相对于 $\mathcal{G}$ 满足 Markov 性和忠实性.

证明. 第一条陈述直接由命题 7.1 蕴含，第二条由定义 6.24 中 Markov 等价的定义得到. □

基于独立性的方法（也称基于约束的方法）假设分布相对于底层图满足 Markov 性和忠实性，然后估计正确的 Markov 等价类；见第 7.2.1 节. 我们在例 6.42 中看到，对高斯分布，因果效应可用单个数 (6.20) 概括. 如果只知道正确图的 Markov 等价类而不

[1] 类似于命题 7.1 的陈述可见 Druzdzel 与 Simon [1993] 及 Druzdzel 与 van Leijen [2001].

知道图本身，该量便不再可识别；不过可以给出界［Maathuis 等, 2009］.

7.1.2 加性噪声模型

命题 7.1 表明，给定分布可能由不同图的多个 SCM 蕴含. 但对其中许多图结构，结构赋值中的函数 f_j 相当复杂. 如果不允许任意复杂的函数，即限制函数类，就会得到非平凡的可识别性结果. 如第 4 章所见，在后面的第 7.1.4 和 7.1.5 节我们将假设噪声以加性方式作用.

定义 7.3（ANM） 若 SCM $\mathfrak{C}$ 的结构赋值形如

$$X_j := f_j(\mathbf{PA}_j) + N_j, \qquad j = 1, \dots, d, \tag{7.1}$$

即噪声是加性的，就称该 SCM 为 ANM. 为简单起见，进一步假设函数 f_j 可微，噪声变量 N_j 具有严格为正的密度.[2]

以下一些可识别性结果假设因果极小性（定义 6.33）. 对 ANM，这意味着每个函数 f_j 对其任何一个参数都不是常数. 直观地说，函数应当真正 “依赖” 其参数. 以下命题的证明见附录 C.10.

命题 7.4（因果极小性与 ANM） 考虑由模型 (7.1) 诱导的分布，假设函数 f_j 对其任何一个参数都不是常数，即对所有 j 和 $i \in \mathbf{PA}_j$，存在变量 $\mathbf{PA}_j \setminus \{i\}$ 的某个值 $pa_{j,-i}$ 和某些 $x_i \neq x_i'$，使得

$$f_j(pa_{j,-i}, x_i) \neq f_j(pa_{j,-i}, x_i').$$

那么联合分布相对于对应图满足因果极小性. 反之，如果存在节点 j, i 使得对所有 $pa_{j,-i}$，函数 $f_j(pa_{j,-i}, \cdot)$ 都是常数，则因果极小性被违背.

我们在注 6.6 中指出，可以将自身限制于对任何一个参数都不是常数的函数；见命题 6.49. 现在看到，对噪声具有完全支撑的 ANM，这一限制蕴含因果极小性.

给定式 (7.1) 描述的受限 SCM 类，是否获得完全的结构可识别性？答案仍是否定的. 例如，定理 4.2 和问题 7.13 表明，如果分布由线性高斯 SCM 诱导，我们不一定能够恢复正确的图. 不过这个情形是例外，意义如下：对几乎所有其他函数和分布的组合，都能获得可识别性. 所有不可识别情形都已得到刻画［Zhang 与 Hyvärinen, 2009；Peters 等, 2014］. 图 4.2 右图展示了另一个不同于线性高斯情形的不可识别例子；其细节见 Peters 等 [2014，例 25]. 表 7.1 展示一些已知的可识别性结果.

再次指出，ANM 框架有若干扩展. 例如 Zhang 与 Hyvärinen [2009] 允许对变量作后非线性变换，Peters 等 [2011a] 考虑离散变量的 ANM.

一般而言，非线性 ANM 对边缘化不封闭. 也就是说，如果 $P_{X,Y,Z}$ 容许从 X 到 Y 和从 Y 到 Z 的 ANM，$P_{X,Z}$ 不一定容许从 X 到 Z 的 ANM. 这可能限制 ANM 在实践中的适用性，因为因果路径上的中间变量未必都被观测到. 对物理实验，可以说任何影响都通过无穷多个中间变量传播. 因此不存在绝对意义上的直接或间接效应（它必须相对于被观测集合而言）. 从这个意义上说，ANM 只能看作良好近似.

接下来的三个小节将更详细地考察三个特定的可识别例子：等误差方差的线性高斯情形（第 7.1.3 节）、线性非高斯情形（第 7.1.4 节）和非线性高斯情形（第 7.1.5 节）.

[2]例如，这两个条件保证 $X_1, \dots, X_d$ 的联合分布具有严格为正的密度.

结构赋值类型	赋值	函数条件	DAG 可识别	参见
（一般）SCM	$X_j := f_j(\mathbf{X}_{\mathbf{PA}_j}, N_j)$	—	否	命题 7.1
ANM	$X_j := f_j(\mathbf{X}_{\mathbf{PA}_j}) + N_j$	非线性	是	定理 7.7(i)
CAM	$X_j := \sum_{k\in\mathbf{PA}_j} f_{jk}(X_k) + N_j$	非线性	是	定理 7.7(ii)
线性高斯	$X_j := \sum_{k\in\mathbf{PA}_j} \beta_{jk} X_k + N_j$	线性	否	问题 7.13
线性高斯、等误差方差	$X_j := \sum_{k\in\mathbf{PA}_j} \beta_{jk} X_k + N_j$	线性	是	命题 7.5

表 7.1：高斯噪声情形下一些已知可识别性结果的总结．非高斯噪声的可识别性结果也已得到，但技术性更强．

虽然已有更一般的结果［Peters 等, 2014］，我们集中讨论这两个例子，因为对它们容易给出精确条件．我们省略证明，着重于结论．大部分证明可以基于 Peters 等 [2011b] 开发的技术，使第 4 章得到的许多双变量可识别性结果推广到多变量情形．

译注：本段先列出三个例子，源文后称“两个，照源保留．表 *7.1* 的可识别性简表须结合相应定理的具体假设，而非无条件保证．

7.1.3 等误差方差的线性高斯模型

还有另一种对线性高斯结构方程模型的偏离使图可识别．Peters 与 Bühlmann [2014] 表明，将噪声变量限制为具有相同方差，足以恢复图结构．证明见该文．

命题 7.5（等误差方差下的可识别性） 考虑图为 $\mathcal{G}^0$、赋值为

$$X_j := \sum_{k\in\mathbf{PA}_j^{\mathcal{G}^0}} \beta_{jk} X_k + N_j, \qquad j = 1, \dots, d,$$

的 SCM，其中所有 N_j 独立同分布且服从高斯分布；特别地，噪声方差 σ^2 不依赖于 j．此外，要求对每个 $j \in \{1, \dots, p\}$，所有 $k \in \mathbf{PA}_j^{\mathcal{G}^0}$ 都满足 $\beta_{jk} \neq 0$．那么图 $\mathcal{G}^0$ 可从联合分布识别．

译注：源命题 *7.5* 和定理 *7.6* 均在变量指标使用 d 后把本条件写作 p；此处保留源符号差异，未假定作者另有未声明的 $p = d$ 约定．本节末对模型 *(7.2)* 的引用指向下一节原编号．

为估计系数 β_{jk}（从而估计图结构），Peters 与 Bühlmann [2014] 提议使用基于 Bayesian 信息准则（BIC）的惩罚最大似然评分（另见第 7.2.2 节），以及 DAG 空间中的贪心搜索算法．改变变量尺度会改变误差项的方差，因此在许多应用中，模型 (7.2) 不能合理地应用．不过，BIC 允许将该方法的评分与使用更多参数、且不假设等误差方差的线性高斯 SCM 的评分进行比较．

7.1.4 线性非高斯无环模型

Shimizu 等 [2006] 使用独立成分分析（ICA）［Comon, 1994，定理 11］证明以下陈述；该 ICA 结果本身使用 Darmois–Skitovič 定理证明．

定理 7.6（LiNGAM 的可识别性） 考虑图为 $\mathcal{G}^0$、赋值为

$$X_j := \sum_{k \in \mathbf{PA}_j^{\mathcal{G}^0}} \beta_{jk} X_k + N_j, \qquad j = 1, \ldots, d, \tag{7.2}$$

的 SCM，其中所有 N_j 联合独立，服从具有严格为正密度的非高斯分布.[3] 此外，要求对每个 $j \in \{1, \ldots, p\}$，所有 $k \in \mathbf{PA}_j^{\mathcal{G}^0}$ 都满足 $\beta_{jk} \neq 0$. 那么图 $\mathcal{G}^0$ 可从联合分布识别.

作者将此模型称为 LiNGAM. 如第 4.1.3 节所述，定理 7.6 还有另一种证明：Peters 等 [2014] 的定理 28 将定理 4.2 等双变量可识别性结果推广到多变量情形. 非线性加性模型也使用这一技巧（通过推广定理 4.5）.

7.1.5 非线性高斯加性噪声模型

我们已经看到，如果 ANM 的赋值是线性的且噪声变量非高斯，其图结构可识别. 另一种方法是利用非线性. 对高斯噪声，结果最容易表述如下.

定理 7.7（非线性高斯 ANM 的可识别性）

(i) 设 $P_{\mathbf{X}} = P_{X_1,\ldots,X_d}$ 由具有赋值 $X_j := f_j(\mathbf{PA}_j) + N_j$ 的 SCM 诱导，其中噪声变量 $N_j \sim \mathcal{N}(0, \sigma_j^2)$，函数 f_j 三次可微，且在以下意义下对任何分量都不是线性的：将 X_j 的父节点 $\mathbf{PA}_j$ 记为 $X_{k_1}, \ldots, X_{k_\ell}$，则对所有 a 以及某些 $x_{k_1}, \ldots, x_{k_{a-1}}, x_{k_{a+1}}, \ldots, x_{k_\ell} \in \mathbb{R}^{\ell-1}$，假设以下函数是非线性的：

$$f_j(x_{k_1}, \ldots, x_{k_{a-1}}, \cdot, x_{k_{a+1}}, \ldots, x_{k_\ell}).$$

(ii) 作为特例，设 $P_{\mathbf{X}} = P_{X_1,\ldots,X_d}$ 由具有赋值

$$X_j := \sum_{k \in \mathbf{PA}_j} f_{j,k}(X_k) + N_j \tag{7.3}$$

的 SCM 诱导，其中噪声变量 $N_j \sim \mathcal{N}(0, \sigma_j^2)$，函数 $f_{j,k}$ 三次可微且非线性. 此模型称为因果加性模型（CAM）.

在 (i)、(ii) 两种情况下，对应图 $\mathcal{G}^0$ 都可从分布 $P_{\mathbf{X}}$ 识别. 如果允许源节点（即没有父节点的节点）的噪声分布具有在实数轴 $\mathbb{R}$ 上完全支撑的非高斯密度，陈述仍成立（证明完全相同）. 证明见 Peters 等 [2014，推论 31].

7.1.6 观测数据与实验数据

第 6.3 节已经看到，底层分布变化时，知道因果关系有助于改善预测. 现在反过来利用这一思想，说明如何通过在不同环境中观测系统来学习因果关系. 考虑以下设置：我们观测来自不同环境 $e \in \mathcal{E}$ 的数据，对应模型为

$$\mathbf{X}^e = (X_1^e, \ldots, X_d^e) \sim P^e,$$

其中每个变量 X_j^e 表示在环境 $e \in \mathcal{E}$ 中测量的同一个（物理）量. 我们将谈论不同环境中的变量 X_j；这稍微滥用了记号.

[3] 严格正密度条件可以放弱（见 ICA 证明的细节），但例如噪声变量非退化这一假设无疑是必要的.

第一类方法假设不同环境来自不同的干预设置. 当干预目标 $I^e \subseteq \{1,\dots,d\}$ 已知时，已有若干方法. 例如 Tian 与 Pearl [2001]、Hauser 与 Bühlmann [2012] 均假设忠实性，分别考虑机制变化和随机干预. 他们定义并刻画了图的干预等价类，即能够解释给定分布的图所构成的类. 例如，对机制变化，可以在模型中加入干预节点，令其子节点为被干预的变量. 这样增加了 v 结构的数量；如果两个图具有相同骨架与 v 结构，且被干预的节点具有相同父节点，那么两个图（相对于给定分布）干预等价［参见 Tian 与 Pearl, 2001，定理 2］. Eberhardt 等 [2010] 允许硬干预与随机干预，即使在存在环时亦然.

Hyttinen 等 [2012] 分析了使图可识别的干预条件. Eberhardt 等 [2005] 和 Hauser 与 Bühlmann [2014] 研究最坏情况下识别图需要多少次干预实验.

现在转向稍有不同的设置：我们不尝试学习完整因果结构，而是考虑目标变量 Y 及其 d 个预测变量构成的集合 $\mathbf{X}$，并试图学习哪些预测变量是 Y 的因果父节点. 在不同环境 $e \in \mathcal{E}$ 中同时观测 $\mathbf{X}$ 和 Y；这些环境可以是干预目标未知的干预设置. 即对 $e \in \mathcal{E}$ 有

$$(\mathbf{X}^e, Y^e) \sim P_{\mathbf{X}^e, Y^e} =: P^e.$$

关键假设是存在未知集合 $\mathbf{PA}_Y \subseteq \{1,\dots,d\}$（可以将其视为 Y 的直接原因），使给定 $\mathbf{PA}_Y$ 的 Y 的条件分布在所有环境中不变，即对所有 $e, f \in \mathcal{E}$，

$$P_{Y^e|\mathbf{PA}_Y^e} = P_{Y^f|\mathbf{PA}_Y^f}.$$

如果分布由底层 SCM 诱导，且不同环境对应于未对 Y 干预的不同干预分布，那么该假设成立［Peters 等, 2016］（例子见代码片段 7.11）. 不过，该设置更一般：环境不一定对应干预，甚至不要求存在底层 SCM. 可以考虑所有产生“不变预测”的变量集合 $S \subseteq \{1,\dots,d\}$ 所构成的集合族 $\mathcal{S}$，即对所有 $e, f \in \mathcal{E}$ 和所有 $S \in \mathcal{S}$，

$$P_{Y^e|S^e} = P_{Y^f|S^f}. \tag{7.4}$$

这里 $Y^e \mid S^e$ 简记 $Y^e \mid \mathbf{X}_S^e$. 不难看出（问题 7.15），出现在所有这些 $S \in \mathcal{S}$ 中的变量必定是 Y 的直接原因：

$$\bigcap_{S \in \mathcal{S}} S \subseteq \mathbf{PA}_Y, \tag{7.5}$$

其中定义对空指标集的交集为空集. Peters 等 [2016] 将式 (7.5) 左侧作为 $\mathbf{PA}_Y$ 的估计. 式 (7.5) 因而保证该方法输出中任何变量确实属于 $\mathbf{PA}_Y$. 在 SCM 和干预的特例中，存在使 $\mathbf{PA}_Y$ 可识别的充分条件［Peters 等, 2016］，即式 (7.5) 取等号. 有趣的是，第 7.2.5 节介绍的方法能够识别数据是否来自这种可识别情形，不需要预先假设这一点.

Tian 与 Pearl [2001] 也讨论了干预目标未知时的可识别性；他们不指定目标变量，而关注边缘分布的变化，而非条件分布的变化.

7.2 结构识别的方法

我们已经看到，一些假设可以使因果结构（部分）可识别. 本节旨在说明如何利用这些假设，从有限数据构造底层图的估计量（两个例子见图 7.1）. 我们概述各种方法，尽量着重介绍其思想. 可用方法非常多，我们认为未来研究需要表明哪些方法在实践中最有用. 尽管如此，我们仍试图指出一些方法的潜在问题和最关键假设. 虽然有些论文研究了所介绍方法的一致性，我们省略大部分此类结果，只介绍思想. 算法实现中的细节也不讨论，感兴趣的读者可参阅所列文献. Kalisch 等 [2012] 维护 R [R Core Team, 2016] 的软件包 `pcalg`；它不仅包含 PC 算法（以提出者 Peter Spirtes 和 Clark Glymour 命名，见第 7.2.1 节）的代码，还包含许多所述方法的代码.

在详细介绍已有方法之前，先作两点说明. （1）虽然已有若干模拟研究，损失函数问题却很少受到关注：给定真实底层因果结构，一个估计因果图有多“好”？实践中常使用结构 Hamming 距离的变体 [Acid 与 de Campos, 2003；Tsamardinos 等, 2006]，它计算设定错误的边的数量. 另一种方法是 Peters 与 Bühlmann [2015] 提出的、根据图预测干预分布的能力评价图. （2）我们介绍的一些方法假设结构赋值（6.1），特别是对应函数 f_j 是简单的. 这些方法通常不仅给出因果结构的估计，也给出相应赋值的估计，后者一般还可用于计算残差. 原则上，在该模型下可以检验噪声变量相互独立的强假设（定义 3.1），例如应用相互独立性检验 [例如 Pfister 等, 2017]；有关此类步骤的统计细节，见第 4.2.1 节.

7.2.1 基于独立性的方法

基于独立性的方法，例如归纳因果（IC）算法、SGS 算法（以提出者 Spirtes、Glymour 和 Scheines 命名）以及 PC 算法，假设分布忠实于底层 DAG. 这使 Markov 等价类，即对应的 CPDAG，可识别（见第 7.1.1 节）. 图中的 d 分离与 $P_{\mathbf{X}}$ 中的条件独立性一一对应，因此对任何 d 分离陈述的查询都可以通过检查对应的条件独立性检验来回答. 我们先假设一个预言机对条件独立性问题给出正确答案，之后在“条件独立性检验”段讨论一些有限样本问题.

多数基于独立性的方法首先估计骨架，即无向边，随后尽可能为边定向. 对骨架搜索，以下引理很有用 [见 Verma 与 Pearl, 1991，引理 1]：

引理 7.8 以下两个陈述成立.

(i) DAG $(\mathbf{X}, E)$ 中两个节点 X, Y 相邻，当且仅当不存在子集 $S \subseteq V \setminus \{X, Y\}$ 能将它们 d 分离.

(ii) 如果 DAG $(\mathbf{X}, E)$ 中两个节点 X, Y 不相邻，那么 $\mathbf{PA}_X$ 或 $\mathbf{PA}_Y$ 可将它们 d 分离.

利用引理 7.8(i)，如果两个变量无论以哪些其他变量为条件都始终依赖，则它们必定相邻. IC 算法 [Pearl, 2009] 和 SGS 算法 [Spirtes 等, 2000] 使用了这一结果. 对每对节点 (X, Y)，这些方法搜索所有既不含 X 也不含 Y 的变量子集 $A \subseteq \mathbf{X} \setminus \{X, Y\}$，检查给

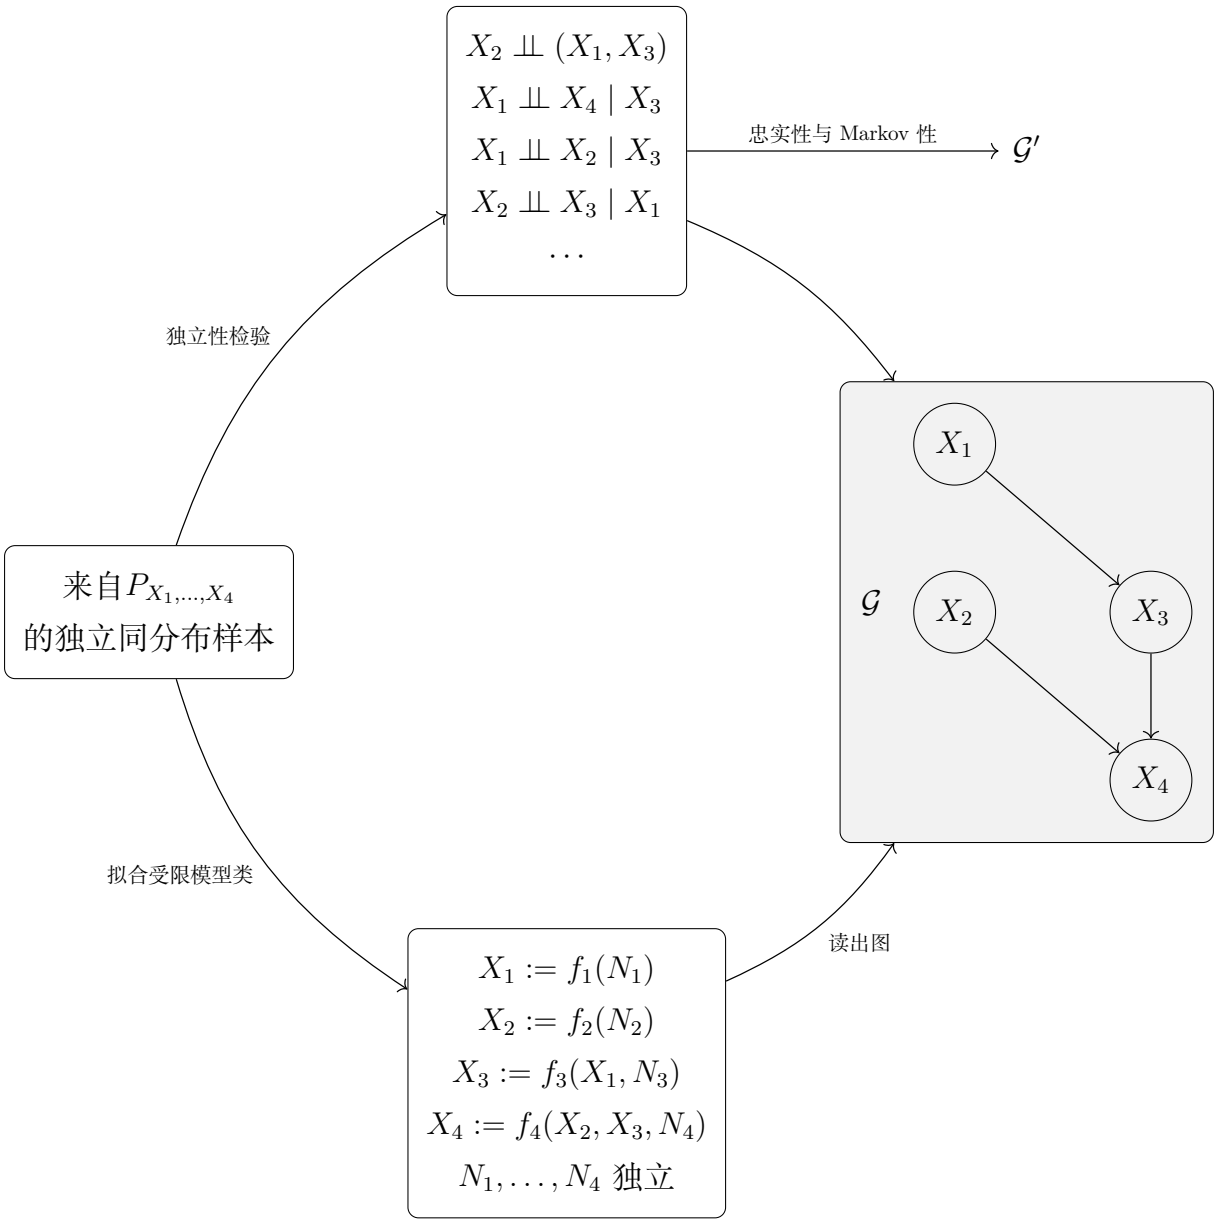


图 7.1: 识别因果结构的两种方法. 上方基于独立性的方法检验数据的条件独立性，这些性质通过 Markov 条件和忠实性与图结构联系起来. 图通常不是唯一可识别的，因此方法可能输出不同的图 $\mathcal{G}$ 和 $\mathcal{G}'$. 另一种方法是限制模型类并直接拟合 SCM（下方）.

定 A 时 X, Y 是否被 d 分离. 所有检验之后，X, Y 相邻当且仅当找不到可将它们 d 分离的集合 A.

搜索所有可能的子集 A 看似并非最优，尤其当图稀疏时. PC 算法 [Spirtes 等, 2000] 从完全连接的无向图出发，从 $\#A = 0$ 开始逐步增加条件集 A 的大小. 在第 k 次迭代中，它考虑大小为 $\#A = k$ 的集合，并使用以下巧妙技巧：为检验能否 d 分离 X, Y，只需遍历 X 的邻居集合或 Y 的邻居集合的子集 A. 这一思路基于引理 7.8(ii)，显然可以减少计算时间，尤其对稀疏图而言.

引理 6.25 表明，我们应该能够对图中的非道德结构（或 v 结构）定向. 如果所得骨架中两个节点不直接相连，则存在一个将它们 d 分离的集合. 假设骨架含有结构 $X - Z - Y$，且 X, Y 之间没有直接边；又设 A 将 X, Y d 分离. 当且仅当 $Z \notin A$ 时，$X - Z - Y$ 是非道德结构，因而可以定向为 $X \to Z \leftarrow Y$. 定向非道德结构后，还可能为了避免有向环等目的对更多边定向. 已证明一组这样的定向规则是完备的，它们称为 Meek 定向规则 [Meek, 1995] .

上述图形方法的一个替代方案是将因果学习表述为可满足性（SAT）问题 [Triantafillou 等, 2010] . 首先将图关系表述为布尔变量，例如 A :=“存在从 X 到 Y 的直接边”. 非平凡的部分是把独立性陈述（仍假设由独立性预言机提供）作为 d 分离陈述转化为涉及布尔变量以及 “与”、“或” 运算符的 “公式”. SAT 问题问的是能否给每个布尔变量赋值 “真” 或 “假”，使整个公式为真. SAT 求解器不仅检查这一点，还告知在所有使整个公式为真的赋值中，某些变量是否总取相同值. 例如，d 分离陈述可能由不同赋值对应的不同图结构满足，但如果在所有这样的赋值中上述布尔变量 A 都为 “真”，便可推断在底层图中 X 必定是 Y 的父节点. 虽然布尔 SAT 问题已知是非确定性多项式时间（NP）完全的 [Cook, 1971; Levin, 1973]，即它既属于 NP 又是 NP 难的，但启发式算法可以求解含数百万变量的大型问题实例. 因果学习中的 SAT 方法允许查询诸如祖先关系的特定陈述，而不必估计整个图；它们允许纳入不同类型的先验知识. 如果认为某些（统计）发现彼此矛盾，还可以给独立性约束赋权. 这些方法已推广到有环结构、潜变量和变量集重叠的数据集 [Hyttinen 等, 2013; Triantafillou 与 Tsamardinos, 2015] .

前面三段假设存在一个独立性预言机，告诉我们分布中是否存在特定（条件）独立性. 然而，实践中必须从有限数据推断这一陈述，带来两个主要挑战. （1）所有基于条件独立性检验的因果发现方法都从依赖和独立中得出结论；但实践中最常用的统计显著性检验本质上是不对称的. 因而人们通常不再使用显著性水平原本的含义，而是将其当作调节参数. 此外，由于样本有限，检验结果甚至可能相互矛盾，即不存在一个图结构能够精确编码所有推断出的条件独立性. （2）尽管近期已有一些基于核检验的工作 [Fukumizu 等, 2008; Tillman 等, 2009; Zhang 等, 2011]，使用有限数据进行非参数条件独立性检验仍然困难. 因此人们常将自身限制在可能依赖关系的某个子类中，下面简要介绍其中一些.

如果假设变量服从高斯分布，可以检验偏相关是否为零（见附录 A.1、A.2）. 在忠实性下，底层 DAG 的 Markov 等价类可识别（引理 7.2）；事实上，在高斯情形下，结合零偏相关检验的 PC 算法给出正确 CPDAG 的一致估计量 [Kalisch 与 Bühlmann,

2007]．进一步假设称为强忠实性的条件 [Zhang 与 Spirtes, 2003；Uhler 等, 2013]，甚至可以得到一致收敛意义下的一致性（uniform consistency）[Kalisch 与 Bühlmann, 2007]；另见 Robins 等 [2003] 的讨论.

非参数条件独立性检验在理论和实践中都是难题. 对非高斯分布，偏相关为零既不是条件独立的必要条件，也不是充分条件，如下例所示.

例 7.9（条件独立性与偏相关）

(i) 如果分布 $P_{X,Y,Z}$ 由 SCM

$$Z := N_Z, \qquad X := Z^2 + N_X, \qquad Y := Z^2 + N_Y$$

蕴含，其中 $N_X, N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$，则满足

$$X \perp\!\!\!\perp Y \mid Z \qquad \text{且} \qquad \rho_{X,Y|Z} \neq 0.$$

偏相关系数 $\rho_{X,Y|Z}$ 等于 $X - \alpha Z$ 和 $Y - \beta Z$ 的相关系数，其中 α, β 分别是将 X, Y 对 Z 回归时的回归系数. 在此例中 $\alpha = \beta = 0$，因为 X, Y 都与 Z 不相关.

(ii) SCM

$$Z := N_Z, \qquad X := Z + N_X, \qquad Y := Z + N_Y$$

所蕴含的分布 $P_{X,Y,Z}$，其中 $(N_X, N_Y) \perp\!\!\!\perp N_Z$，且 N_X, N_Y 不相关但不独立，满足

$$X \not\perp\!\!\!\perp Y \mid Z \qquad \text{且} \qquad \rho_{X,Y|Z} = 0,$$

因为此处 $\rho_{X,Y|Z}$ 是 N_X, N_Y 的相关系数.

因此，偏相关为零既不蕴含条件独立，也不由条件独立蕴含.

以下检验给定 Z 时 X, Y 是否条件独立的步骤，是偏相关的自然非线性推广 [例如 Ramsey, 2014]：(1) 将 X 对 Z 作（非线性）回归，检验残差与 Y 是否独立；(2) 将 Y 对 Z 作（非线性）回归，检验残差与 X 是否独立；(3) 如果两种独立性有一种成立，则判定 $X \perp\!\!\!\perp Y \mid Z$. 对 ANM，这似乎是正确的检验；见第 7.1.2 节. 例如，对三个变量有以下结果.

命题 7.10 考虑 ANM（定义 7.3）诱导的分布 $P_{X,Y,Z}$，所有变量都具有严格为正的密度. 若给定 Z 时 X, Y 被 d 分离，则上述步骤输出对应的条件独立性，意义是 $X - E[X \mid Z]$ 与 Y 独立，或 $Y - E[Y \mid Z]$ 与 X 独立.

证明. 假设 $X := h(Z) + N_X$ 和 $Y := f(Z) + N_Y$，其中 Z, N_X, N_Y 相互独立. 那么 $X - E[X \mid Z] = N_X$ 与 Y 独立. 对其他可能的结构，例如 $X \to Z \to Y$ 或 $X \leftarrow Z \leftarrow Y$，陈述类似地成立. □

译注：源证明的等式 $X - E[X \mid Z] = N_X$ 一般还需 $E[N_X] = 0$；非零均值时残差为 $N_X - E[N_X]$，独立性结论仍可在均值存在时讨论. 随后源文先列变量 V，图中却用 W，保留此记号差异.

该命题表明，对三个变量的 ANM，上述检验（在总体意义下）是适当的. 然而，考虑四个变量 X, Y, Z, V 就可能出现问题. 显然，图 $X \leftarrow Z \to W \to Y$ 和 $X \to Z \to W \to Y$

Markov 等价. 但对第一个图，检验输出 $X \perp\!\!\!\perp Y \mid Z$；对第二个图却没有这样的保证. 因此，为构造可行的条件独立性检验而对随机变量间的依赖模型施加上述限制，会导致对 Markov 等价类内的图作不对称处理. 许多其他类型的条件独立性检验方法也可能有同样效果. 这种不对称不一定是缺点：如前所见，受限函数类可能使 Markov 等价类内部具有可识别性（见第 7.1 节）. 但这一点确实需要考虑.

7.2.2 基于评分的方法

上一节直接利用独立性陈述推断图. 另一种方法是检验不同图结构拟合数据的能力. 其理由是，例如编码了错误条件独立性的图结构会产生不良的模型拟合. 尽管基于评分的因果学习方法可能具有更早的渊源，我们主要参考 Geiger 与 Heckerman [1994a]、Heckerman 等 [1999]、Chickering [2002] 及其参考文献. Max-Min Hill-Climbing 算法 [Tsamardinos 等, 2006] 结合了基于评分和基于独立性的技术.

给定来自变量向量 $\mathbf{X}$ 的数据 $D = (X^1, \ldots, X^n)$，即包含 n 个独立同分布观测值的样本，思路是给每个图 $\mathcal{G}$ 赋予评分 $S(D, \mathcal{G})$，并在 DAG 空间中搜索评分最高的图：

$$\widehat{\mathcal{G}} := \underset{\mathcal{G} \text{ 为} \mathbf{X} \text{ 上的 DAG}}{\arg\max} \; S(D, \mathcal{G}). \tag{7.6}$$

定义评分函数 S 有多种可能. 人们常假设一个参数模型（例如线性高斯方程或多项分布），从而引入参数集合 $\theta \in \Theta$.

对每个图，可以考虑 θ 的最大似然估计量 $\hat{\theta}$，再用 BIC 定义评分函数

$$S(D, \mathcal{G}) = \log p(D \mid \hat{\theta}, \mathcal{G}) - \frac{\#\text{参数}}{2} \log n, \tag{7.7}$$

其中 $\log p(D \mid \hat{\theta}, \mathcal{G})$ 是对数似然，n 是样本量. 输出（惩罚）似然最大的图的估计量通常是一致的；这由 BIC 的一致性 [Haughton, 1988] 及模型类的可识别性得到. 但为了保证收敛速率，通常依赖于 “可识别程度” [例如 Bühlmann 等, 2014]. 实践中可能无法在所有图中找到评分最高者，因此需要在图空间中使用搜索技术（例如见 “贪心搜索技术” 段）. 也可以采用不同于 BIC 的正则化. 例如 Roos 等 [2008] 基于最小描述长度原则 [Grünwald, 2007] 构造评分. 利用 Haughton [1988] 的工作，Chickering [2002] 讨论了 BIC 方法与下面介绍的 Bayesian 表述之间的关系.

分别在 DAG 和参数上定义先验 $p^{\mathrm{pr}}(\mathcal{G})$ 和 $p^{\mathrm{pr}}(\theta)$，并将对数后验作为评分函数（注意对所有 DAG，$p(D)$ 均为常数）：

$$S(D, \mathcal{G}) := \log p(\mathcal{G} \mid D) \propto \log p^{\mathrm{pr}}(\mathcal{G}) + \log p(D \mid \mathcal{G}),$$

其中 $p(D \mid \mathcal{G})$ 是边缘似然

$$p(D \mid \mathcal{G}) = \int_{\theta \in \Theta} p(D \mid \mathcal{G}, \theta) p^{\mathrm{pr}}(\theta \mid \mathcal{G}) \, d\theta.$$

此时式 (7.6) 得到的估计量 $\widehat{\mathcal{G}}$ 是后验分布的众数，通常称为最大后验（MAP）估计量. 也可以输出 DAG 上的完整后验分布，原则上甚至可以得到更详细的信息. 例如，可以对所有图取平均，得到特定边存在的后验概率.

译注：*Bayes* 公式在取对数后给出的是相差加法常数 $-\log p(D)$，一般不是乘法正比. 此处保留源文 $\propto$，评分比较应按相差图无关常数理解.

例如考虑只取有限多个值的随机变量. 给定结构 $\mathcal{G}$，可以假设对每种父节点配置，随机变量 X_j 的概率分布服从多项分布. 如果对其参数设定 Dirichlet 先验（并附加一些有关参数独立性和模块性的条件），就得到 Bayesian Dirichlet（BD）评分 [Geiger 与 Heckerman, 1994b].

在参数模型情形下，如果对每个参数 θ_1 都有对应参数 θ_2，使得图 $\mathcal{G}_1$ 与 θ_1 组合所得分布等于图 $\mathcal{G}_2$ 与 θ_2 组合所得分布，反之亦然，我们称两个图 $\mathcal{G}_1, \mathcal{G}_2$ 分布等价. 例如可以证明（见问题 7.12），在线性高斯情形下两个图分布等价当且仅当它们 Markov 等价. 因此有人认为，对 Markov 等价的图 $\mathcal{G}_1, \mathcal{G}_2$，$p(D \mid \mathcal{G}_1)$ 和 $p(D \mid \mathcal{G}_2)$ 应当相同. 可以调整 BD 评分使其满足这一性质，通常称为 Bayesian Dirichlet 等价（BDe）评分 [Geiger 与 Heckerman, 1994b]. Buntine [1991] 提出了该评分一个超参数更少的具体版本.

所有 DAG 的搜索空间随变量数量超指数增长 [例如 Chickering, 2002]. 对 2、3、4 和 10 个变量，DAG 数分别为 3、25、543 和 4175098976430598143（见表 B.1）. 因此，通过搜索所有图来计算式 (7.6) 的解往往不可行. 可以改用贪心搜索算法求解：每一步有一个候选图和一组邻近图，对所有邻居计算评分，并将评分最高的图作为新候选. 如果没有邻居得到更好的评分，搜索终止（但不知道所得是否只是局部最优）. 因此显然需要定义邻域关系. 例如从图 $\mathcal{G}$ 出发，可以将通过删除、添加或反转一条边得到的所有图定义为其邻居.

在线性高斯 SCM 中，不能区分 Markov 等价的图. 此时将搜索空间从 DAG 改为 Markov 等价类是有利的. 贪心等价搜索（GES）[Chickering, 2002] 优化 BIC 准则 (7.7)，从空图开始，分两个阶段：第一阶段添加边，直到达到局部最大值；第二阶段删除边，直到达到局部最大值，并将其作为算法输出.

一般而言，寻找评分最优的 DAG 是 NP 难的 [Chickering, 1996]；但仍有大量有趣的研究尝试扩大精确方法的规模. 这里 “精确” 指对给定有限数据集力图找到（一个）评分最高的图. 贪心搜索技术通常是启发式的，即使有保证，也往往只在无限数据极限下成立.

一条研究路线基于动态规划 [Silander 与 Myllymak, 2006；Koivisto 与 Sood, 2004；Koivisto, 2006]. 这些方法利用实践中许多评分的可分解性：由 Markov 因子分解，对 $D = (X^1, \dots, X^n)$ 有

$$\log p(D \mid \hat{\theta}, \mathcal{G}) = \sum_{j=1}^{d} \sum_{i=1}^{n} \log p(X_j^i \mid X^i_{\mathbf{PA}_j^{\mathcal{G}}}, \hat{\theta}),$$

这是 d 个 “局部” 评分之和. 基于动态规划的方法利用这种可分解性；尽管具有指数复杂

度，它们仍可找到不少于 30 个变量的评分最高的图，即使不限制父节点数量亦然. 考虑到这一变量数目对应的不同 DAG 的巨大数量（见表 B.1），这是值得注意的结果.

整数线性规划（ILP）框架不仅假设可分解性，还假设评分函数对 Markov 等价图给出相同评分. 其思路是把图结构表示为向量，使评分函数在此向量表示中成为仿射函数. Studený 与 Haws [2014] 描述 Hemmecke 等 [2012] 如何基于特征 imset 构造表示，而 Jaakkola 等 [2010] 和 Cussens [2011] 则使用指示节点间父子关系的（指数长度）零一编码，并利用 De Campos 与 Ji [2011] 的工作缩小搜索空间. 将问题表述为 ILP 后，它仍然是 NP 难的，但此时可以使用现成的 ILP 方法. 限制父节点数量带来进一步进展；例如在 “谱系学习” 中，每个节点最多有两个父节点 [Sheehan 等, 2014] .

7.2.3 加性噪声模型

可以通过结合贪心搜索技术的评分方法学习 ANM. 这已被用于等误差方差的线性高斯模型（第 7.1.3 节）和非线性高斯 ANM（第 7.1.5 节）[见 Peters 与 Bühlmann, 2014；Bühlmann 等, 2014] . 例如在非线性高斯情形下，可以类似于双变量情形处理（见式 (4.18)、(4.19)）. 对给定图结构 $\mathcal{G}$，将每个变量对其父节点回归，得到评分

$$\log p(D \mid \mathcal{G}) = \sum_{j=1}^{d} -\log \widehat{\mathrm{var}}[R_j];$$

这里 $\widehat{\mathrm{var}}[R_j]$ 是将变量 X_j 对其父节点回归得到的残差 R_j 的经验方差. 直观地说，模型拟合数据越好，残差方差越小，评分因而越大. 形式上，这一过程是最大似然的一个实例，可以证明它是一致的 [Bühlmann 等, 2014] . 在计算上，仍可利用评分可分解为不同节点之和的性质：计算仅改变一个变量父节点集合的邻近图的评分时，只需更新对应求和项. 如果不能假设噪声服从高斯分布，例如可以估计噪声分布 [Nowzohour 与 Bühlmann, 2016]，得到类似熵的评分.

译注：源式把对数似然写成负对数残差方差之和，常见高斯样本总对数似然还包含样本量、比例因子和常数；这里保留原评分归一化记号. 不能在未检查归一化前与另一种总似然数值直接比较.

也可以利用独立性检验迭代估计结构. Mooij 等 [2009] 和 Peters 等 [2014] 提出回归后进行独立性检验（RESIT）. 该方法基于噪声变量与所有在其之前的变量独立这一性质. 对线性非高斯模型（第 7.1.4 节），Shimizu 等 [2006] 给出基于 ICA [Comon, 1994；Hyvärinen 等, 2001] 的实用方法，适用于有限数据. 后来 Shimizu 等 [2011] 提出了该方法的改进版本.

7.2.4 已知因果顺序

寻找底层因果模型的因果顺序（见附录 B）往往困难. 然而，给定因果顺序后，图估计就简化为 “经典” 的变量选择. 例如假设

$$X := N_X, \qquad Y := f(X, N_Y), \qquad Z := g(X, Y, N_Z),$$

其中 f, g, N_X, N_Y, N_Z 未知. 此时判断 f 是否依赖 X、g 是否依赖 X 和 / 或 Y（见注 6.6 的结构极小性假设），是 “传统” 统计学中已得到充分研究的显著性问题. 可以使用标

准方法，特别是在作出线性等进一步结构假设时［例如 Hastie 等, 2009；Bühlmann 与 van de Geer, 2011］. 这一观察此前已有提出［例如 Teyssier 与 Koller, 2005；Shojaie 与 Michailidis, 2010］；有人建议，不在 DAG 空间中搜索，而先搜索因果顺序再进行变量选择，可能更有利［例如 Teyssier 与 Koller, 2005；Bühlmann 等, 2014］.

7.2.5 观测数据与实验数据

第 7.1.6 节说明，当我们在不同条件（“环境”）下观测系统时，因果结构如何变得可识别. 现在讨论仅给定有限数据时如何在实践中利用这些结果. 假设对每个环境 $e \in \mathcal{E}$ 得到一个样本 $\mathbf{X}^e_{n_e}$，即在每个环境中观测 n_e 个独立同分布数据点.

此处每个设置对应一个干预实验. 我们还知道干预目标 $I^e \subseteq \{1, \dots, p\}$. Cooper 与 Yoo [1999] 将干预效应作为机制变化纳入 Bayesian 框架. 对完全干预，Hauser 与 Bühlmann [2015] 考虑线性高斯 SCM，提出贪心干预等价搜索（GIES），即第 7.2.2 节简述的 GES 算法的修改版本.

有时无法在每次实验中测量所有变量(即使所有实验都是观测性的,也可能如此),但仍希望合并可用数据中的信息. 基于 SAT 的方法已处理这一问题［例如见 Triantafillou 与 Tsamardinos, 2015；Tillman 与 Eberhardt, 2014 及其中参考文献］.

Eaton 与 Murphy [2007] 不假设不同干预的目标已知. 相反，他们对每个环境 $e \in \mathcal{E}$ 引入一个没有入边的干预节点 I_e（见第 6.3 节 “干预变量”）；每个数据点只有一个干预节点活跃. 然后在干预节点没有父节点的约束下，对具有 $d + \#\mathcal{E}$ 个变量的扩展模型使用标准方法.

Tian 与 Pearl [2001] 提议检验边缘分布是否在不同设置中改变，并利用这一信息推断部分图结构；他们还将此方法与基于独立性的方法结合.

第 7.1.6 节还考虑了从 d 个预测变量构成的集合 $\mathbf{X}$ 中估计目标变量 Y 的因果父节点的问题. 我们定义集合族 $\mathcal{S}$，其中包含所有满足不变预测的集合 $S \subseteq \{1, \dots, d\}$，即 $P_{Y^e|S^e}$ 在所有环境 $e \in \mathcal{E}$ 中保持不变的集合；见式 (7.4). 实践中，可以在水平 α 下检验不变预测假设，并收集所有通过检验的集合 S，作为对 $\mathcal{S}$ 的估计 $\widehat{\mathcal{S}}$. 由于真实父节点集 $\mathbf{PA}_Y \subseteq \mathbf{X}$ 以高概率 $(1-\alpha)$ 属于 $\widehat{\mathcal{S}}$，得到覆盖陈述

$$\bigcap_{S \in \widehat{\mathcal{S}}} S \subseteq \mathbf{PA}_Y \tag{7.8}$$

以高概率 $(1-\alpha)$ 成立. 式 (7.8) 左侧是一种称为 “不变因果预测” 的方法的输出［Peters 等, 2016］. 代码片段 7.11 展示环境对应不同干预的例子（方法并不要求如此）. 要获得式 (7.8) 意义下的正确覆盖，只需对给定 $\mathbf{PA}_Y$ 的 Y 的条件分布建模；特别地，不对 d 个预测变量 $\mathbf{X}$ 的分布作任何假设. 这不同于 Eaton 与 Murphy [2007] 的方法（见 “未知干预目标” 段），后者还尝试估计完整因果结构.

代码片段 7.11 以下代码展示两个环境中的因果系统. 在真实底层结构中，X_1, X_2 是 Y 的原因，而 Y 是 X_3 的原因. 对合并数据的线性模型（第 13 行），所有变量 X_1, X_2, X_3

都高度显著，因为它们都是 Y 的良好预测变量. 然而这种模型不是不变的. 在两个环境中，将 Y 对 X_1, X_2, X_3 回归分别得到系数 $-0.15, 1.09, -0.39$ 和 $-0.32, 1.62, -0.54$. 不变因果预测方法仅输出 Y 的因果父节点，即 X_1, X_2. 在本例中，$\{1, 2\}$ 是唯一产生不变模型的集合，即 $\widehat{\mathcal{S}} = \{\{1, 2\}\}$.

```
library(InvariantCausalPrediction)
#
# generate data from two environments
env <- c(rep(1,400),rep(2,700))
n <- length(env)
set.seed(1)
X1 <- rnorm(n)
X2 <- 1*X1 + c(rep(0.1,400), rep(1.0,700))*rnorm(n)
Y <- -0.7*X1 + 0.6*X2 + 0.1*rnorm(n)
X3 <- c(rep(-2,400),rep(-1,700))*Y + 2.5*X2 + 0.1*rnorm(n)
#
summary(lm(Y~-1+X1+X2+X3))
# Coefficients:
# ----Estimate Std.Error t.val. Pr(>|t|)
# X1 -0.396212 0.008667 -45.71 <2e-16 ***
# X2 +1.381497 0.021377 +64.63 <2e-16 ***
# X3 -0.410647 0.011152 -36.82 <2e-16 ***
#
ICP(cbind(X1,X2,X3),Y,env)
#lower bd upper bd p-value
# X1 -0.71 -0.68 3.7e-06 ***
# X2 +0.59 +0.61 0.0092 **
# X3 -0.00 +0.00 0.2972
```

译注：源正文将线性回归调用指为第 *13* 行，而源代码实际调用在第 *12* 行. 此处保留源句及代码，不通过重排代码掩盖行号差异.

7.3 习题

问题 7.12（高斯 SCM） 证明对线性高斯 SCM，两个图 $\mathcal{G}_1, \mathcal{G}_2$ 分布等价当且仅当它们 Markov 等价. 这里允许系数为零.

问题 7.13（高斯 SCM） 考虑由线性高斯 SCM $\mathfrak{C}$ 诱导的 $\mathbf{X} = (X_1, \ldots, X_d)$ 的分布 $P_{\mathbf{X}}$，其密度为 p. 证明对任何使 $P_{\mathbf{X}}$ 满足 Markov 性的 DAG $\mathcal{G}$，都存在对应线性高斯 SCM $\mathfrak{C}_{\mathcal{G}}$ 蕴含 $P_{\mathbf{X}}$.

问题 7.14（ANM） 证明 $\mathbf{X} = (X_1, \ldots, X_d)$ 上的 ANM，如果函数 f_j 可微且噪声变量具有严格为正的密度，则蕴含的 $\mathbf{X}$ 的分布也具有严格为正的密度（见定义 7.3）.

问题 7.15（不变因果预测） 证明式 (7.5).

Chapter 8

与机器学习的联系，II

如第 5 章所述，统计模型底层的因果结构可能对半监督学习或领域适应等机器学习任务产生重大影响. 现在重新讨论这一一般主题，重点关注多变量情形. 我们首先介绍一种对给定因果结构利用机器学习建模系统误差的方法，接着讨论强化学习（包括计算广告中的应用），最后简述领域适应.

8.1 半同胞回归

该方法利用给定因果结构（见图 8.1）减少预测任务中的系统噪声，目标是重建未观测的信号 Q. Schölkopf 等 [2015] 提议，从信号 Y 中去除能够由同一噪声源污染的其他测量 $\mathbf{X}$ 解释的全部信息，以对 Y 去噪. 这里 $\mathbf{X}$ 是与 Q 独立的某些信号 $\mathbf{R}$ 的测量值. 直观地说，Y 中能由 $\mathbf{X}$ 解释的一切必定来自系统噪声 N，因此应当去除. 更准确地说，我们将

$$\widehat{Q} := Y - E[Y \mid \mathbf{X}]$$

作为 Q 的估计. 这里 $E[Y \mid \mathbf{X}]$ 是将 Y 对其半同胞 $\mathbf{X}$ 的回归（注意 $\mathbf{X}, Y$ 具有共同父节点 N；见图 8.1）.

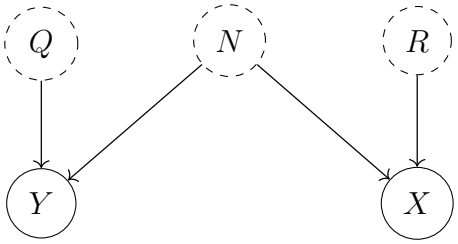


图 8.1: 适用于系外行星搜索问题的因果结构. 感兴趣的底层信号 Q 只能以含噪版本 Y 测得. 如果同一噪声源也污染与 Q 独立的其他信号的测量，这些测量可用于去噪. 在本例中，望远镜 N 构成系统噪声，影响独立光变曲线的测量 X, Y. 虚线节点未观测，实线节点已观测；Q, N, R 分别为真实信号、系统噪声和其他信号.

可以证明，对满足 $Q \perp\!\!\!\perp \mathbf{X}$ 的任意随机变量 $Q, \mathbf{X}, Y$，有 [Schölkopf 等, 2016，命题 1]

$$E\left[(Q - E[Q] - \widehat{Q})^2\right] \leq E\left[(Q - E[Q] - (Y - E[Y]))^2\right],$$

即该方法绝不比直接使用测量 Y 更差. 如果系统噪声还以加性方式作用，即对某个（未知）函数 f 有 $Y = Q + f(N)$，则 [Schölkopf 等, 2016，命题 3]

$$E\left[(Q - E[Q] - \widehat{Q})^2\right] = E[\mathrm{var}[f(N) \mid \mathbf{X}]]. \tag{8.1}$$

如果加性噪声是 $\mathbf{X}$ 的函数，即对某个（未知）函数 ψ 有 $f(N) = \psi(\mathbf{X})$，则式 (8.1) 右侧为零，从而 $\widehat{Q}$ 恢复 Q，相差一个加性平移；其他充分条件见 Schölkopf 等 [2016].

作为例子，考虑寻找系外行星. 2009 年发射的 Kepler 空间天文台在寻找系外行星时观测了银河系的一小部分，监测约 150000 颗恒星的亮度.[1] 若一颗恒星周围有轨道适宜、能够部分遮挡恒星的行星，其光变曲线会显示光强的周期性下降，见图 8.2. 这些测量受到望远镜造成的系统噪声污染，使可能的行星信号难以探测.

幸运的是，望远镜同时测量许多恒星. 由于这些恒星相距数光年，可以假设它们因果独立，因而统计独立. 因此图 8.1 所示因果结构非常适合这一问题，可以应用半同胞回归. 这个简单方法表现出人意料地好［Schölkopf 等, 2015］.

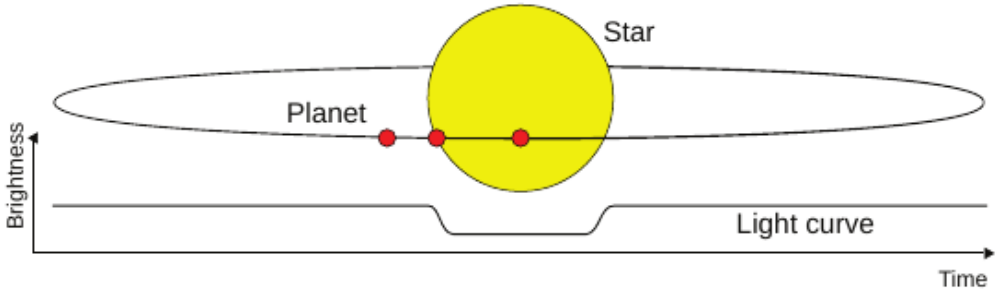


图 8.2: 每当行星遮挡恒星的一部分时，光强就会下降. 如果行星绕恒星运行，这一现象周期性发生. 图内英文分别表示恒星、行星、亮度、光变曲线和时间. 图片由 Nikola Smolenski 提供, https://en.wikipedia.org/wiki/File:Planetary_transit.svg, 许可 CC BY-SA 3.0；原书为清晰和风格调整了图片.

相关方法已在其他应用领域使用，并未提及因果建模［Gagnon-Bartsch 与 Speed, 2012；Jacob 等, 2016］. 考虑问题的因果结构（图 8.1）会直接提示所提方法，并给出支持该方法的理论论证.

8.2 因果推断与分幕式强化学习

现在从因果角度描述强化学习中的一类问题. 粗略地说，在强化学习中，智能体处于一个世界之中，从一组不同行动中作选择. 这些行动取决于世界的当前状态，会产生某种奖励并改变世界状态. 智能体的目标是最大化期望累积奖励（更多细节见第 8.2.2 节）. 我们首先介绍已经应用于机器学习和统计学不同语境的逆概率加权概念，然后将其与分幕式强化学习联系起来. 建立这种联系是连接因果性与强化学习的第一小步. 因果视角使我们能够利用直接由因果结构得到的条件独立性. 我们简要提及两个应用——二十一点和广告投放——并说明它们如何受益于因果知识. 因果表述非常自然地带来这些方法改进，但显然也可以不使用因果语言表述这些问题和相应算法. 本节并不证明强化学习受益于因果性；我们将其视为在两个领域之间建立形式联系的一步，未来可能带来富有成果的研究［例如另见 Bareinboim 等, 2015］. 更具体地说，我们相信在强化学

[1] https://en.wikipedia.org/wiki/Kepler_(spacecraft)，访问日期 2016-07-13.

习的不同任务之间迁移知识时，因果性可能发挥作用（例如电子游戏进入下一关，或乒乓球比赛更换对手）；但我们不知道有这样的结果.

8.2.1 逆概率加权

逆概率加权是一种众所周知的技术，用于从服从不同分布的样本估计某个分布的性质，因此它自然地与因果推断相关. 考虑肾结石例子（例 6.37）. 我们定义了二元变量大小 S、治疗 T 和康复 R；得到观测数据后，我们关心的是一个所有人都接受治疗 A 的假设研究中的期望康复率 $\widetilde{E}[R]$，即不同分布下的期望. 形式上，考虑变量 $\mathbf{X} = (X_1, \dots, X_d)$ 上蕴含分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 的 SCM $\mathfrak{C}$. 我们曾指出，人们常常观测到来自观测分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 的样本，却关心某个干预分布 $P_{\mathbf{X}}^{\widetilde{\mathfrak{C}}}$. 这里的新 SCM $\widetilde{\mathfrak{C}}$ 通过对原 SCM $\mathfrak{C}$ 的节点 X_k 干预而构造，例如

$$do\Big(X_k := \tilde{f}(X_{\widetilde{\mathbf{PA}}_k}, \widetilde{N}_k)\Big);$$

见第 6.3 节. 特别地，我们可能希望估计新分布 $P_{\mathbf{X}}^{\widetilde{\mathfrak{C}}}$ 的某一性质

$$\widetilde{E}\,\ell(\mathbf{X}) := E_{P_{\mathbf{X}}^{\widetilde{\mathfrak{C}}}}\ell(\mathbf{X})$$

（在肾结石例子中，这是 $\widetilde{E}[R]$）. 如果密度存在，我们在第 6.3 节看到 $\mathfrak{C}, \widetilde{\mathfrak{C}}$ 的密度以类似方式因子分解：

$$\begin{aligned} p(x_1, \dots, x_d) &:= p^{\mathfrak{C}}(x_1, \dots, x_d) = \prod_{j=1}^{d} p^{\mathfrak{C}}(x_j \mid x_{pa(j)}), \\ \tilde{p}(x_1, \dots, x_d) &:= p^{\widetilde{\mathfrak{C}}}(x_1, \dots, x_d) = \prod_{j \neq k} p^{\mathfrak{C}}(x_j \mid x_{pa(j)})\, \tilde{p}(x_k \mid x_{\widetilde{pa}(k)}). \end{aligned}$$

两种因子分解除被干预变量对应的项外均一致，因此

$$\begin{aligned} \xi := \widetilde{E}\,\ell(\mathbf{X}) &= \int \ell(\mathbf{x})\tilde{p}(\mathbf{x})\, d\mathbf{x} = \int \ell(\mathbf{x})\frac{\tilde{p}(\mathbf{x})}{p(\mathbf{x})}p(\mathbf{x})\, d\mathbf{x} \\ &= \int \ell(\mathbf{x})\frac{\tilde{p}(x_k \mid x_{\widetilde{pa}(k)})}{p(x_k \mid x_{pa(k)})}p(\mathbf{x})\, d\mathbf{x}. \end{aligned}$$

（为简单起见，整节均假设密度严格为正.）给定从分布 $P_{\mathbf{X}}^{\mathfrak{C}}$ 抽取的样本 $\mathbf{X}^1, \dots, \mathbf{X}^n$，通过重新加权观测值，可以构造 $\xi = \widetilde{E}\,\ell(\mathbf{X})$ 的估计量

$$\hat{\xi}_n := \frac{1}{n}\sum_{i=1}^{n} \ell(\mathbf{X}^i)\frac{\tilde{p}(X_k^i \mid X_{\widetilde{pa}(k)}^i)}{p(X_k^i \mid X_{pa(k)}^i)} = \frac{1}{n}\sum_{i=1}^{n} \ell(\mathbf{X}^i)w_i. \tag{8.2}$$

这里权重 w_i 定义为条件密度之比. 在 $P_{\mathbf{X}}^{\widetilde{\mathfrak{C}}}$ 下具有高似然的数据点（它们 “可能从” 感兴趣的新分布中抽得）获得较大权重，对估计 $\hat{\xi}_n$ 的贡献大于权重较小的数据点. 例如，这种估计量出现在以下三种情形.

(i) 假设 $\mathbf{X} = (Y, Z)$ 仅包含目标变量 Y 和因果协变量 Z，即 $Z \to Y$. 考虑对 Z 干预及函数 $\ell(\mathbf{X}) = \ell((Z, Y)) = Y$. 则估计量 (8.2) 简化为

$$\hat{\xi}_n := \frac{1}{n} \sum_{i=1}^{n} Y^i \frac{\tilde{p}(Z^i)}{p(Z^i)}, \tag{8.3}$$

称为 Horvitz–Thompson 估计量 [Horvitz 与 Thompson, 1952]. 该设置对应于协变量偏移假设 [例如 Shimodaira, 2000; Quionero-Candela 等, 2009; Ben-David 等, 2010]; 另见第 5.2 节和第 8.3 节. 估计量 (8.3) 是加权似然估计量的例子.

(ii) 对 $\mathbf{X} = Z$，可以使用从 p 采样的数据估计 $\tilde{p}$ 下的期望 $\widetilde{E}[\ell(Z)]$. 因而式 (8.2) 简化为

$$\hat{\xi}_n := \frac{1}{n} \sum_{i=1}^{n} \ell(Z^i) \frac{\tilde{p}(Z^i)}{p(Z^i)},$$

这个公式称为重要性采样 [例如 MacKay, 2002, 第 29.2 节]. 如果 $p, \tilde{p}$ 只知道相差常数的形式，公式可以作相应调整.

(iii) 我们将在分幕式强化学习的语境中使用式 (8.2)，下面稍详细地描述这一应用.

8.2.2 分幕式强化学习

强化学习 [例如 Sutton 与 Barto, 2015] 对智能体在世界中采取行动的行为建模. 例如，世界状态根据世界当前状态 S_t 和行动 A_t 按 Markov 决策过程变化 [例如 Bellman, 1957]，即进入新状态 s 的概率 $P(S_{t+1} = s)$ 只依赖于当前状态 S_t 和行动 A_t. 此外，智能体会得到某个依赖 S_t, A_t, S_{t+1} 的奖励 R_{t+1}; 所有奖励之和有时称为回报，记为 $Y := \sum_t R_t$. 回报 Y 如何依赖状态和行动对智能体来说是未知的; 智能体试图改进其策略 $(a, s) \mapsto \pi(a \mid s) := P(A_t = a \mid S_t = s)$，即其所选行动以世界状态的观测部分为条件的分布. 在分幕式强化学习中，有限次行动后状态会重置（见图 8.3）. 第 8.2.3 节考虑二十一点的例子. 在图 8.3 的例子中，玩家作出 $K = 3$ 次决定，之后重新洗牌，再开始新的一幕.

假设按照某个策略 $(a, s) \mapsto \pi(a \mid s)$ 玩 n 局，每局为一幕. 函数 π 不依赖迄今已走的 “步数”，只依赖状态的值. 只要该策略为任何行动赋予正概率，式 (8.2) 就允许估计另一个策略 $(a, s) \mapsto \tilde{\pi}(a \mid s)$ 的表现:

$$\hat{\xi}_{n,\mathrm{ERL}} := \frac{1}{n} \sum_{i=1}^{n} Y^i \frac{\prod_{j=1}^{K} \tilde{\pi}(A_j^i \mid S_j^i)}{\prod_{j=1}^{K} \pi(A_j^i \mid S_j^i)}. \tag{8.4}$$

这可以看作离策略评估的一种 Monte Carlo 方法 [Sutton 与 Barto, 2015, 第 5.5 节]. 实践中估计量 (8.4) 的方差往往很大; 在连续情形下方差甚至可能无穷. 有人提议重新加权 [Sutton 与 Barto, 2015] 或丢弃最大的（五个）权重 [Bottou 等, 2013]，以偏差换取方差降低. Bottou 等 [2013] 还在参数化密度情形下计算置信区间和梯度; 如果希望搜索最优策略，后者很重要.

下面简要讨论两个例子，其中利用因果结构提高学习过程的统计性能. 我们认为这些例子很有意思，能帮助理解强化学习与因果性之间的关系.

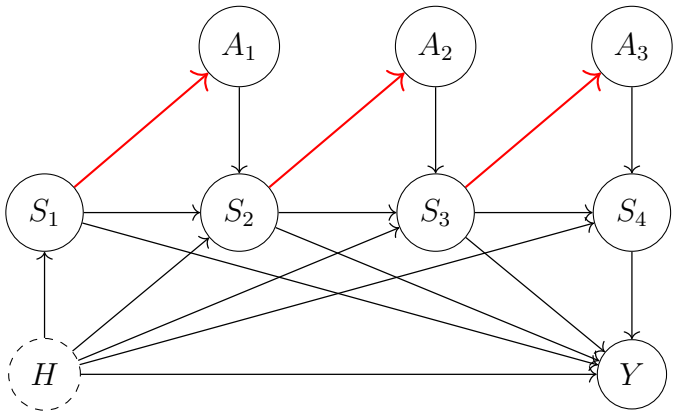


图 8.3: 分幕式强化学习问题. 行动变量 A_i 影响系统下一状态 S_{i+1}. 变量 Y 描述一幕结束后的输出或回报；它也可能依赖行动（为清晰起见未画出这些边），通常建模为每次决策后所得奖励的（可能加权）和，见第 8.2.3 节. 整个系统可能受到未观测变量 H 的混杂. 红色粗边表示玩家能够影响的条件分布，即策略. 式 (8.4) 利用策略 π 下得到的数据估计策略 $\tilde{\pi}$ 下的期望结果 $\widetilde{E}[Y]$. 即使从行动 A 到 H 和 / 或 Y 有额外边，该式仍成立.

8.2.3 二十一点中的状态简化

第 8.2.2 节提出的方法可用于学习如何玩二十一点（一种纸牌游戏）. 假设玩家进入赌场并开始玩二十一点，既不知道游戏目标，也不知道最优策略，而是采用随机策略. 游戏中的每个时刻，都会询问玩家希望采取哪一种合法行动；游戏结束后，庄家公布玩家赢了或输了多少钱. 经过一段时间，玩家可能将策略更新为倾向于已证明成功的决策，然后继续游戏. 从数学角度看，二十一点已经得到解决：Baldwin 等 [1956] 找到了（无穷多副牌时的）最优策略，对下注 1 欧元的玩家，它得到期望 $E[Y] \approx -0.006$ 欧元.

因果性如何发挥作用？我们假设玩家不知道二十一点的确切规则；不过他或许知道输赢只由牌的点数决定，与花色无关，即规则不区分梅花皇后和红桃皇后. 玩家便可立即得出最优策略不依赖花色. 这在搜索最优策略时带来明显好处：相关状态空间的数量，因而可能策略的空间，大幅减少. 图 8.4 描绘了这一论证：变量 S_t 包含全部信息，而变量 F_t 不包含花色. 例如

$$S_3 = (\text{玩家：} \heartsuit K,\ \spadesuit 5,\ \diamondsuit 4; \quad \text{庄家：} \diamondsuit K),$$
$$F_3 = (\text{玩家：} K, 5, 4; \quad \text{庄家：} K).$$

由于最终结果 Y 仅依赖 $(F_1, \ldots, F_4)$ 而不依赖 “完整状态” $(S_1, \ldots, S_4)$，可以选择让行动依赖 F 变量. 类似地，也可以利用牌的顺序同样无关这一事实. 更形式化地，有以下结果.

译注：源图显示 $S_1, F_1 \to A_1$ 等，而图注用 A_j 依赖 S_{j-1}, F_{j-1}；二者索引不同，此处分别保留. 命题 *8.1* 的转移条件 *(8.6)* 未显式以行动为条件，不能据简写自动补强其适用范围；证明缺口另见附录 *C.11*.

命题 8.1（状态简化） 假设我们关心回报 $Y := \sum_j R_j$，且所有变量都是离散的. 假设

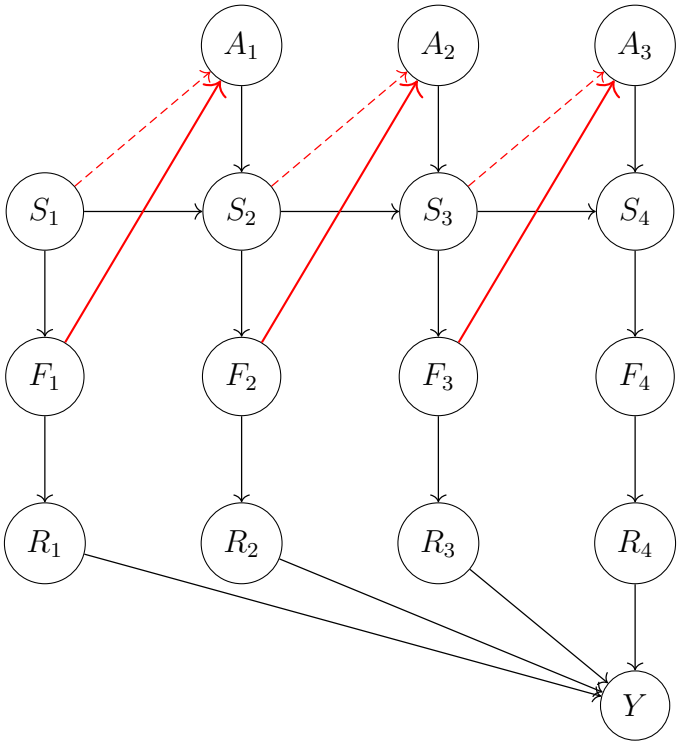


图 8.4: 存在变量 $F_1, \ldots, F_4$，在式 (8.5) 和 (8.6) 成立的意义下，包含关于状态 $S_1, \ldots, S_4$ 的全部相关信息. 式 (8.6) 未在图中表示. 此时行动 A_j 依赖 F_{j-1}（红色实线）而非 S_{j-1}（红色虚线）即可. 在二十一点例子中，S_j 编码庄家和玩家的手牌，包括花色；F_j 编码同样的信息但不包括花色（花色不影响二十一点的结果）. 由于 F_j 可取的值比 S_j 少，最优策略更易学习.

存在函数 f，使对所有 j 和 $F_j := f(S_j)$ 有

$$R_j \perp\!\!\!\perp S_j \mid F_j, A_j, \tag{8.5}$$

并且完整状态在以下意义下对状态变化无关紧要：对所有 s_j，以及满足 $f(s_{j-1}) = f(s^\circ_{j-1})$ 的所有 s_{j-1}, s°_{j-1}，有

$$p(f(s_j) \mid s_{j-1}) = p(f(s_j) \mid s^\circ_{j-1}). \tag{8.6}$$

那么最优策略 $(a, s) \mapsto \pi_{\text{opt}}(a \mid s)$ 只依赖 F_j，不依赖 S_j. 存在

$$\pi_{\text{opt}} \in \arg\max_{\pi} E[Y],$$

使得

$$\pi_{\text{opt}}(a_j \mid s_{j-1}) = \pi_{\text{opt}}(a_j \mid s^\circ_{j-1}) \quad \forall s_{j-1}, s^\circ_{j-1} : f(s_{j-1}) = f(s^\circ_{j-1}).$$

如果 F_j 的取值比 S_j 少，这一结果特别有帮助. 证明见附录 C.11. 在二十一点例子中，式 (8.6) 指出抽到另一张 K 的概率只依赖先前抽到的牌的点数（尤其是 K 的数量），而不依赖花色.

8.2.4 广告投放中的改进加权

Bottou 等 [2013] 在广告最优投放中使用了相关论证. 考虑对该系统的以下简化描述. 一家公司（我们称为发布商）运营搜索引擎，希望在搜索结果上方的主区域展示广告. 只有用户点击广告时，发布商才会从对应公司收款. 展示广告之前，发布商设定主区域保留值 A：这是一个实值参数，决定主区域展示多少广告. 在大多数系统中，主区域广告数量 F 在 0 到 4 之间，即 $F \in \{0, 1, 2, 3, 4\}$. 主区域保留值 A 通常取决于许多变量（例如搜索查询、查询的日期和时间、地点），我们称之为状态 S. 例如，如果搜索查询表明用户打算买新鞋，人们可能希望展示比用户查找下一次教堂礼拜时间时更多的广告. 可以把该系统建模为幕长为 1 的分幕式强化学习.[2] 回报 Y 等于每幕的点击次数，值为 0 或 1. 如何选择最优主区域保留值 A，对应于寻找最优策略 $(a, s) \mapsto \pi_{\text{opt}}(a \mid s)$. 图 8.5 展示简化问题的图示.

状态 S 包含发布商可获得的用户信息；隐藏变量 H 包含未知的用户信息（例如其意图），行动 A 为主区域保留值，Y 表示用户是否点击某条广告. 最后，F 是表示展示多少条广告的离散变量. 评估新策略 $(a, s) \mapsto \tilde{p}(a \mid s)$ 相当于应用式 (8.4)：

$$\hat{\xi}_{n,\text{ERL}} := \frac{1}{n} \sum_{i=1}^{n} Y^i \frac{\tilde{p}(A^i \mid S^i)}{p(A^i \mid S^i)}.$$

（这里为记号方便写 $p(a \mid s)$，而非 $\pi(a \mid s)$.）现在可以利用以下关键洞见：用户是否点击广告依赖主区域保留值 A，但只通过 F 的值发生依赖. 用户从未看到实值参数 A. 考

[2] 现实中的系统通常更复杂. 例如，在类似拍卖的过程中，广告商对某些搜索查询出价，继而影响每次点击的价格.

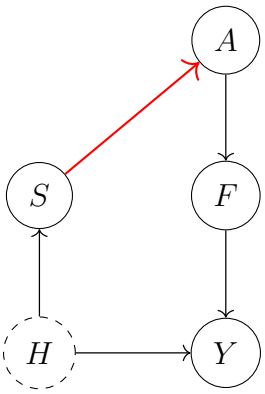


图 8.5: 广告投放的例子. 目标变量 Y 表示用户是否点击展示的某个广告. H（未知）和 S（已知）是状态变量；行动 A 对应主区域保留值，它是决定主区域展示多少广告的实值参数. F 是表示主区域广告（已知）数量的离散变量. 虽然随机化的是条件分布 $p(a \mid s)$，但可以使用 $p(f \mid s)$ 重新加权（见命题 8.2）.

虑系统的因果结构（见图 8.5）时，这是一个相当直接的观察. 利用这一事实，可以使用另一估计量

$$\frac{1}{n}\sum_{i=1}^{n} Y^i \frac{\tilde{p}(F^i \mid S^i)}{p(F^i \mid S^i)};$$

见命题 8.2. 由于 F 是例如取 0 到 4 的离散变量，这通常产生性质好得多的权重. 实践中，这一修改可能大幅缩小置信区间［Bottou 等, 2013，第 5.1 节］. 与第 8.1 节一样，我们可以利用对因果结构的认识提高统计性能. 更形式化地，这一方法由以下命题支持.

命题 8.2（改进加权） 假设存在 $\mathbf{X} = (A, F, H, S, Y)$ 上的密度 p，它由图如图 8.5 所示的 SCM $\mathfrak{C}$ 蕴含. 进一步假设密度 $\tilde{p}$ 由对应于形式为 $do(A := \tilde{f}(S, \widetilde{N}_A))$ 的 A 干预的 SCM $\widetilde{\mathfrak{C}}$ 蕴含，并满足当 $p(f \mid s) = 0$ 时 $\tilde{p}(f \mid s) = 0$、当 $p(a \mid s) = 0$ 时 $\tilde{p}(a \mid s) = 0$. 那么

$$\widetilde{E}Y = \int y \frac{\tilde{p}(a \mid s)}{p(a \mid s)} p(\mathbf{x})\, d\mathbf{x} = \int y \frac{\tilde{p}(f \mid s)}{p(f \mid s)} p(\mathbf{x})\, d\mathbf{x}.$$

证明见附录 C.12. 一般而言，密度不为零的条件确实必要：如果存在属于 $\tilde{p}$ 的支撑、且对 Y 的期望有贡献的一组 a, s 值（具有非零 Lebesgue 测度），则必须存在非零概率在 p 下从该区域采样数据.

译注：源命题把 F 设为离散变量，却统称联合分布为密度并写积分. 这些表达应相对于适当混合参考测度理解，即离散分量求和、连续分量积分；还须满足所用重加权比值的支撑条件.

8.3 领域适应

领域适应是另一个与因果性自然相关的机器学习问题［Schölkopf 等, 2012］. 这里我们将领域适应与第 7.2.5 节 “不同环境” 中所谓的不变预测联系起来. 我们不声称这种联系以当前形式带来重大改进，但相信它可能有助于开发领域适应的新方法.

假设在不同领域 $e \in \mathcal{E} = \{1, \dots, D\}$ 得到目标变量 Y^e 和 d 个可能预测变量 $\mathbf{X}^e = (X_1^e, \dots, X_d^e)$ 的数据，我们关心预测 Y. 为适应广泛使用的记号，使用 “领域” 或 “任务” 这两个术语. 表 8.1 描述这里考虑的三个领域适应问题的分类.

方法	训练数据来自	测试领域
领域泛化	$(\mathbf{X}^1, Y^1), \dots, (\mathbf{X}^D, Y^D)$	$T := D + 1$
多任务学习	$(\mathbf{X}^1, Y^1), \dots, (\mathbf{X}^D, Y^D)$	$T \in \{1, \dots, D\}$
非对称多任务学习	$(\mathbf{X}^1, Y^1), \dots, (\mathbf{X}^D, Y^D)$	$T := D$

表 8.1: 在领域泛化中，测试数据来自未见过的领域；而在多任务学习中，测试领域有一些数据可用.

译注：源文先定义训练领域集合 $\mathcal{E} = \{1, \dots, D\}$，又称式 *(8.7)* 的 $e, f \in \mathcal{E}$ 包含测试领域 $T = D + 1$；此处保留原指标，但测试领域若纳入量词须扩展指标集合.

主要假设是存在集合 $S^* \subseteq \{1, \dots, d\}$，使条件分布 $Y^e \mid \mathbf{X}^e_{S^*}$ 对所有领域 $e \in \mathcal{E}$、包括测试领域都相同，即对所有 $e, f \in \mathcal{E}$ 和所有 x_{S^*}，

$$Y^e \mid \mathbf{X}^e_{S^*} = x_{S^*} \quad \text{与} \quad Y^f \mid \mathbf{X}^f_{S^*} = x_{S^*} \quad \text{具有相同分布.} \tag{8.7}$$

在第 7.1.6 节和第 7.2.5 节，我们考虑了类似设置，使用术语 “环境” 而非 “领域”，并称性质 (8.7) 为 “不变预测”. 我们曾指出，如果存在底层 SCM，且环境对应对目标 Y 以外节点的干预，则当 $S^* = \mathbf{PA}_Y$ 时性质 (8.7) 成立（另参见第 2.2 节对 Simon 不变性判据的讨论）. 不过，该性质对因果父节点以外的集合也可能成立. 由于目标是预测，我们最关心满足 (8.7) 且能尽可能准确地预测 Y 的集合 S^*. 暂且假设给定这样的集合 S^*（稍后回到这一问题），说明假设 (8.7) 与领域适应的关系.

在协变量偏移设置中 [例如 Shimodaira, 2000；Quionero-Candela 等, 2009；Ben-David 等, 2010]，通常假设条件分布 $Y^e \mid \mathbf{X}^e = x$ 在所有任务 e 中不变. 假设 (8.7) 意味着协变量偏移对变量的某个子集 S^* 成立，因而推广了协变量偏移假设.

对于领域泛化，如果集合 S^* 已知，我们便可以对该子集应用传统的协变量偏移方法. 例如，如果输入空间中的数据支撑重叠（或系统是线性的），可在测试领域 T 中使用估计量 $f_{S^*}(\mathbf{X}^T_{S^*})$，其中 $f_{S^*}(x) := E[Y^1 \mid \mathbf{X}^1_{S^*} = x]$. 可以证明，在一种对抗性设置中，这一方法是最优的：测试领域的分布可与训练领域任意不同，但要求条件分布 (8.7) 保持不变 [Rojas-Carulla 等, 2016，定理 1]. 在多任务学习中，如何利用这样一个集合 S^* 的知识不那么明显. 实践中需要结合汇集任务、将 Y 对 S^* 回归所获得的信息，以及单独考虑测试任务所获得的知识 [Rojas-Carulla 等, 2016].

如果 S^* 未知，我们再次建议在可用领域上搜索满足 (8.7) 的集合 S. 学习因果预测变量时，人们倾向于保持保守，因此不变因果预测方法输出满足 (8.7) 的所有集合 S 的交集 [Peters 等, 2016]；见式 (7.5). 这里我们关心的是预测，因此在所有产生不变预测的集合中，可以选择预测性能最好的集合 S，它通常是其中较大的集合之一. 如果有多个已知集合 S 都满足 (8.7)，同样适用. 如果数据由 SCM 生成且领域对应不同干预，可以证明在无限数据极限下，满足 (8.7) 且预测能力最好的集合 S 是 Y 的 Markov 毯的子集（见问题 8.5）.

8.4 习题

问题 8.3（半同胞回归） 考虑图 8.1 中的 DAG. 除 Y 提供的信息外，X 还提供关于 Q 的额外信息，这一事实由因果忠实性得到. 为什么?

问题 8.4（逆概率加权） 考虑形式为

$$Z := N_Z, \qquad\qquad Y := Z^2 + N_Y,$$

的 SCM $\mathfrak{C}$, 其中 $N_Y, N_Z \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$; 及其干预版本 $\widetilde{\mathfrak{C}}$, 其中 $do(Z := \widetilde{N}_Z)$ 且 $\widetilde{N}_Z \sim \mathcal{N}(2,1)$.

a) (选做) 计算 $E[Y] := E_{P^{\mathfrak{C}}}[Y]$ 和 $\widetilde{E}[Y] := E_{P^{\widetilde{\mathfrak{C}}}}[Y]$.

b) 从 SCM $\mathfrak{C}$ 抽取 $n = 200$ 个独立同分布数据点，实现估计量 (8.3) 来估计 $\widetilde{E}[Y]$.

c) 对从 $n = 5$ 增至 $n = 50000$ 的样本量，计算 b) 中的估计值和式 (8.3) 中权重的经验方差. 可以得出什么结论?

问题 8.5（不变预测变量） 下面证明第 8.3 节末的陈述. 考虑变量 $Y, E, X_1, \ldots, X_d$ 上的 DAG，其中 E (表示 "环境") 不是 Y 的父节点，且自身没有父节点. 用 M 表示 Y 的 Markov 毯. 证明对任何满足 $Y \perp\!\!\!\perp E \mid S$ 的集合 $S \subseteq \{X_1, \ldots, X_d\}$，存在另一集合 $S_{\text{new}} \subseteq M$，使得

$$Y \perp\!\!\!\perp E \mid S_{\text{new}} \qquad \text{且} \qquad Y \perp\!\!\!\perp (S \setminus S_{\text{new}}) \mid S_{\text{new}}.$$

Chapter 9

隐藏变量

到目前为止，我们假设模型中的所有变量（噪声除外）都已测量. 由于实践中随机变量集合由我们自己选择，需要定义 “因果相关” 变量的概念. 因此在第 9.1 节引入 “因果充分性” 和 “干预充分性” 两个术语. 但即使暂不考虑精确定义的细节，显然在大多数实际应用中，许多因果相关变量未被观测. Simpson 悖论（第 9.2 节）说明忽略隐藏混杂如何导致错误的因果结论. 在线性情形中，常称为工具变量的一种结构可以使对应因果效应的回归系数（见例 6.42）可识别（第 9.3 节）. 为具有隐藏变量的 SCM 寻找良好的图形表示，特别是能够编码条件独立结构的表示，是一个活跃的研究领域；我们将在第 9.4 节介绍其中一些解法. 最后，隐藏变量使观测分布中出现超越条件独立性的约束（第 9.5 节）. 我们简述这些约束如何用于结构学习，但不给出方法细节. 关于隐藏变量处理的更多历史说明，参见 Spirtes 等 [2000，第 6.1 节].

9.1 干预充分性

通常，如果不存在隐藏的共同原因 $C \notin \mathbf{X}$ 导致 $\mathbf{X}$ 中多个变量，就称变量集合 $\mathbf{X}$ 因果充分［例如 Spirtes, 2010］. 虽然这一定义符合 “相关” 变量集合的直观含义，但它使用 “共同原因” 概念，因此应相对于更大的变量集合 $\widetilde{\mathbf{X}} \supseteq \mathbf{X}$ 来理解（而我们可能又希望定义后者的因果充分性）. 在对应该更大集合 $\widetilde{\mathbf{X}}$ 的结构因果模型中，如果存在从 C 到 X 和从 C 到 Y 的有向路径，且两条路径分别不包含 Y 和 X，则变量 C 是 X, Y 的共同原因. 共同原因也称混杂因素，我们交替使用这两个术语.

我们提出对因果充分性的一个小修改，称为干预充分性；这一概念基于 SCM 的可证伪性，见第 6.8 节.

定义 9.1（干预充分性） 如果变量集合 $\mathbf{X}$ 上存在一个作为干预模型不能被证伪的 SCM，即它诱导与实践观测一致的观测分布和干预分布，则称 $\mathbf{X}$ 干预充分.

我们认为这一概念在直觉上很有吸引力，因为它描述了变量集合何时足够大，足以在计算观测分布和干预分布的意义下进行因果推理.

如果存在潜在共同原因，只考虑两个变量通常不够充分，这一点应当是直观的. 根据定义，这两个变量因果不充分；第 9.2 节的 Simpson 悖论（另见例 6.37）表明，一般而言这两个变量也不干预充分. 实际上，该悖论将这个陈述推到极端：忽略混杂的、两个观测变量上的 SCM 不仅蕴含错误的干预分布，甚至可能反转因果效应的符号，使有害的治疗看上去有益；见式 (9.2).

不过，有时即使存在潜在混杂，仍能计算正确的干预分布. 下例中的变量集合干预充分，但因果不充分.

例 9.2 考虑 SCM

$$Z := N_Z, \qquad X := \mathbf{1}_{Z \geq 2} + N_X, \qquad Y := Z \bmod 2 + X + N_Y,$$

其中 $N_Z \sim \mathcal{U}(\{0,1,2,3\})$ 是 $\{0,1,2,3\}$ 上的均匀分布，且 $N_X, N_Y \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$；见图 9.1. 虽然变量 X, Y 显然因果不充分，[1] 可以证明这两个变量干预充分. 原因在于 “混杂因素” Z 由两个独立部分组成：$Z_1 := \mathbf{1}_{Z \geq 2}$ 是 Z 的二进制表示的第一个比特，$Z_2 := Z \bmod 2$ 是第二个比特. 在这个意义下，可以把 “混杂因素” 拆分为独立变量 Z_1, Z_2，其中 Z_1 影响 X，Z_2 影响 Y；见图 9.1.

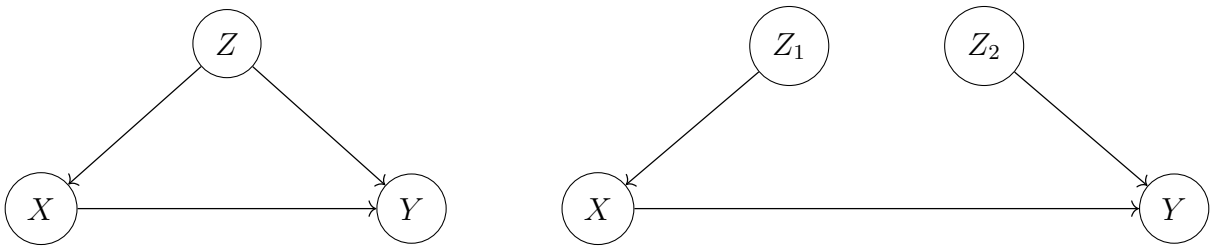


图 9.1: 两图表示例 9.2 所述模型的干预等价 SCM. 虽然只有第二种表示使 X, Y 因果充分，但无论采用哪种表示，X, Y 都干预充分.

一般而言，因果充分性与干预充分性有以下关系（证明见附录 C.13）.

命题 9.3（干预充分性与因果充分性） 设 $\mathfrak{C}$ 是变量 $\mathbf{X}$ 上作为干预模型不能被证伪的 SCM.

(i) 若子集 $\mathbf{O} \subseteq \mathbf{X}$ 因果充分，则它干预充分.

(ii) 一般而言逆命题不成立，即存在干预充分但非因果充分的集合 $\mathbf{O} \subseteq \mathbf{X}$.

此外，例 9.2 表明，无法仅依据图形判据确定变量子集是否干预充分. 对许多结构类似于图 9.1 左图的 SCM，X, Y 干预不充分. 但以下注说明省略 “中间” 变量会保留干预充分性.

注 9.4 有以下三个陈述.

(i) 假设存在 X, Y, Z 上图为 $X \to Y \to Z$、满足 $X \not\perp\!\!\!\perp Z$ 并诱导正确干预的 SCM. 那么由于存在满足 $X \to Z$ 的 X, Z 上 SCM，X, Z 干预充分.

(ii) 假设存在 X, Y, Z 上诱导正确干预的 SCM $\mathfrak{C}$，其图为 $X \to Y \to Z$，并有额外边 $X \to Z$；进一步假设 $P^{\mathfrak{C}}_{X,Y,Z}$ 忠实于该图，另见 (iii). 那么由于存在满足 $X \to Z$ 的 X, Z 上 SCM，X, Z 再次干预充分.

(iii) 若情形与 (ii) 相同，但对所有 x 有

$$P^{\mathfrak{C}}_{Z|X=x} = P^{\mathfrak{C};do(X:=x)}_{Z} = P^{\mathfrak{C}}_{Z}$$

（特别地，$P^{\mathfrak{C}}_{X,Y,Z}$ 不忠实于该图），那么由于存在空图的 X, Z 上 SCM，X, Z 干预充分. 注意，反事实可能无法正确表示.

[1] 此处隐藏共同原因 Z 不仅指向 X, Y，而且对二者都有总因果效应；见定义 6.12.

这些陈述的证明留待读者完成（见问题 9.10）.

每当找到观测变量上的 SCM 与原来所有变量上的 SCM 干预等价时，可以将前者称为边缘化 SCM. 我们已经看到，不存在仅依据图形确定边缘化 SCM 结构的判据；相反，需要一些有关因果机制，即赋值具体形式的信息. Bongers 等 [2016] 更详细地研究了 SCM 的边缘化. 关键思路是从原 SCM 出发，只考虑观测变量的结构赋值；然后每当隐藏变量出现在右侧时，反复代入它们的赋值. 这样得到一个具有多变量、可能依赖噪声变量的 SCM. 在某些情况下，随后可以选择具有单变量噪声变量的干预等价 SCM.

9.2 Simpson 悖论

例 6.16 的肾结石数据集因以下原因广为人知. 我们有

$$\begin{aligned} &P^{\mathfrak{C}}(R=1 \mid T=A) < P^{\mathfrak{C}}(R=1 \mid T=B) \quad \text{但} \\ &P^{\mathfrak{C};do(T:=A)}(R=1) > P^{\mathfrak{C};do(T:=B)}(R=1); \end{aligned} \tag{9.1}$$

见例 6.37. 假设我们没有测量变量 Z（结石大小），甚至不知道它的存在. 那么可能会假设 $T \to R$ 是正确的图. 如果将这个（错误的）SCM 记为 $\widetilde{\mathfrak{C}}$，便可将式 (9.1) 改写为

$$\begin{aligned} &P^{\widetilde{\mathfrak{C}};do(T:=A)}(R=1) < P^{\widetilde{\mathfrak{C}};do(T:=B)}(R=1) \quad \text{但} \\ &P^{\mathfrak{C};do(T:=A)}(R=1) > P^{\mathfrak{C};do(T:=B)}(R=1). \end{aligned} \tag{9.2}$$

由于模型设定错误，因果陈述发生反转. 虽然 A 是更有效的药物，我们却建议使用 B. 但即使知道共同原因 Z，是否可能还有另一个我们未曾调整的混杂变量？如果运气不好，确实如此；纳入该变量后，我们必须再次反转结论. 原则上这可能导致任意长的因果结论反转序列（见问题 9.11）.

该例表明，在写出底层因果图时必须多么谨慎. 在某些情况下，可以从描述数据采集的方案推断 DAG. 例如，如果分配治疗的医生除了肾结石大小之外，对患者没有任何了解，那么除结石大小外就不会有其他混杂因素.

总之，Simpson 悖论与其说是悖论，不如说是一种警告：因果推理可能对模型设定错误极为敏感. 虽然我们在混杂情形下表述这一例子，它也可能由未予考虑的选择偏差（例 6.30）引起.

9.3 工具变量

工具变量可追溯到 20 世纪 20 年代 [Wright, 1928]，并在实践中广泛使用 [例如见 Imbens 与 Angrist, 1994；Bowden 与 Turkington, 1990；Didelez 等, 2010]. 已有许多扩展和替代方法；我们着重于核心思想. 考虑图 9.2 左图所示的线性高斯 SCM. 其中结构赋值 $Y := \alpha X + \delta H + N_Y$ 的系数 α 是感兴趣的量（见例 6.42 的式 (6.18)），有时称为平均因果效应（ACE）. 但由于隐藏共同原因 H，无法直接得到该量. 简单地将 Y 对 X 回归并取回归系数，一般会得到 α 的有偏估计量：

$$\frac{\operatorname{cov}[X,Y]}{\operatorname{var}[X]} = \frac{\alpha \operatorname{var}[X] + \delta\gamma \operatorname{var}[H]}{\operatorname{var}[X]} = \alpha + \frac{\delta\gamma \operatorname{var}[H]}{\operatorname{var}[X]}.$$

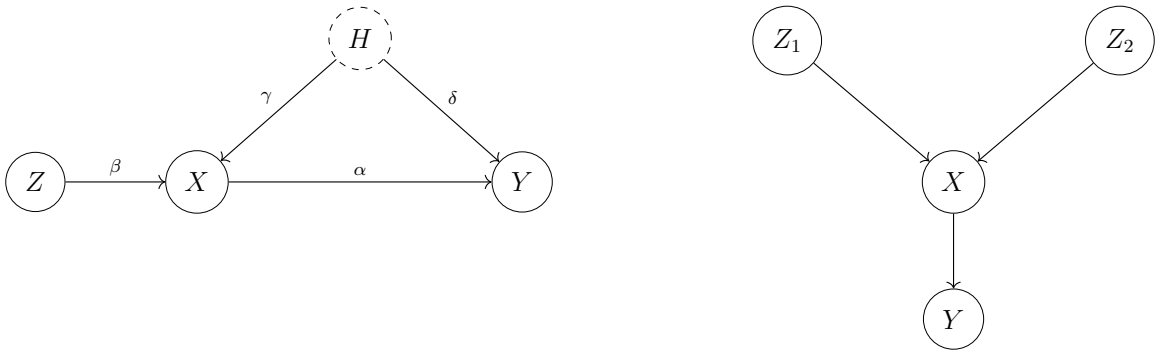


图 9.2: 左：工具变量的设置（第 9.3 节）. 一个著名例子是存在不依从的随机临床试验：Z 为治疗分配，X 为治疗，Y 为结果. 右：Y 结构，见第 9.4.1 节.

相反，我们可能能够利用工具变量——如果它存在. 形式上，如果 SCM 中变量 Z 满足：(a) Z 独立于 H；(b) Z 与 X 不独立（“相关性”）；(c) Z 仅通过 X 影响 Y（“排除限制”），则称 Z 是 (X, Y) 的工具变量. 对我们的目的，考虑满足所有这些假设的图 9.2 左图即可. 但注意其他结构也满足这些假设；例如，可以允许 Z, X 之间有隐藏共同原因. 实践中，人们通常利用领域知识论证条件 (a)、(b)、(c) 成立.

在线性情形中，可以如下利用 Z 的存在. 由于 (H, N_X) 独立于 Z，可以把

$$X := \beta Z + \gamma H + N_X$$

中的 $\gamma H + N_X$ 看作噪声. 因此可以一致估计系数 β，从而得到 βZ（有限数据时用 Z 的拟合值近似）. 由于

$$Y := \alpha X + \delta H + N_Y = \alpha(\beta Z) + (\alpha\gamma + \delta)H + N_Y,$$

译注：上式按源书保留；直接代入 X 的赋值还应出现 αN_X，即完整随机等式右侧还多这一项. 在所述独立性假设下，此遗漏项与 Z 独立，不改变这里总体两阶段回归的系数结论，但原印式并非完整的随机变量等式. 接着可以通过将 Y 对 βZ 回归来一致估计 α. 总之，先将 X 对 Z 回归，再将 Y 对预测值 $\hat{\beta} Z$（从第一步回归得到）回归. 在无限数据极限下，平均因果效应 α 可识别. 这一方法通常称为 “两阶段最小二乘”. 它使用线性 SCM 及上述假设：(a) H, Z 独立；(b) β 非零（β 很小或为零时，Z 称为 “弱工具变量”）；(c) 不存在 Z 对 Y 的直接影响.

但可识别性并不限于线性情形. 尽管还有许多其他结果 [例如 Hernán 与 Robins, 2006]，这里只提及以下四条.

(i) 不难看出，如果 X 以非线性但加性的方式依赖 Z, H，两阶段最小二乘法仍然有效；见问题 9.12.

(ii) 如果变量 Z, X, Y 是二元的，ACE 定义为

$$P^{\mathfrak{C};do(X:=1)}(Y=1) - P^{\mathfrak{C};do(X:=0)}(Y=1).$$

例如不对 Y 与 X, H 的关系作进一步假设，Balke 与 Pearl [1997] 给出 ACE 的（紧）上下界. 这些界可能提供的信息很少，也可能收缩为单个点；在后者情况下，我们称 ACE 可识别.

(iii) Wang 与 Tchetgen Tchetgen [2016] 表明，仍在二元处理情形下，如果 Y 的结构赋值对 X, H 是加性的，则 ACE 可识别［Wang 与 Tchetgen Tchetgen, 2016，定理 1］.

(iv) 连续情形中的可识别性见 Newey [2013] 及其中参考文献.

涉及工具变量的大多数概念（例如前述线性设置）可扩展到观测协变量 W 导致一些或全部相关变量的情形. 例如图 9.2 左图中可以允许变量 W 指向 Z, X, Y. 此时假设 (a)、(b)、(c) 及步骤都需要修改，并始终包含以 W 为条件. Brito 与 Pearl [2002b] 将这一思想扩展到多变量 Z, X（“广义工具变量”）.

9.4 条件独立性与图形表示

在因果学习中，我们试图从观测数据重建因果模型. 已经见过若干可识别性结果，使我们能从观测分布 $P_{\mathbf{X}}$ 识别变量 $\mathbf{X}$ 上 SCM 的图结构. 现在考虑变量 $\mathbf{X} = (\mathbf{O}, \mathbf{H})$ 上的 SCM $\mathfrak{C}$，其中包含观测变量 $\mathbf{O}$ 和隐藏变量 $\mathbf{H}$. 我们仍可询问：能否从观测变量上的分布 $P_{\mathbf{O}}$ 识别 $\mathfrak{C}$ 的图结构？如果能，又该如何识别？

无隐藏变量时，第 7.2.1 节讨论了如何在 Markov 条件和忠实性下学习因果结构的部分信息. 这些假设保证 d 分离与条件独立一一对应，因而可以在 $P_{\mathbf{X}}$ 中检验条件独立，重建底层图的性质. 回顾一下，基于独立性的方法原则上在 DAG 空间中搜索，并输出一个图（或图的等价类），恰好表示数据中找到的条件独立集合.

有隐藏变量时，原则上希望在含潜变量的 DAG 空间中搜索，但这带来额外困难. 我们不知道 $\mathbf{H}$ 的大小；若不限制隐藏变量数，便有无限多个候选图需要搜索. 统计上也有理由反对这种做法：相对于一个 DAG 满足 Markov 性与忠实性的分布集合构成弯曲指数族，这例如为使用 BIC 提供依据［Haughton, 1988］；但相对于含潜变量 DAG 满足这两个条件的分布集合并非如此［Geiger 与 Meek, 1998］. 若无法在含潜变量 DAG 上搜索，能否用观测变量上的边缘化图表示每个此类 DAG，允许使用多种边，再搜索这些结构？第 9.1 节已表明，这也有困难：边缘化图应依赖原底层 SCM，仅考虑原图包含的信息并不足够. 如前所述，Bongers 等 [2016] 更详细地研究了 SCM 的边缘化.

因此，本节余下部分稍微改变问题：不再检查完整分布能否由某个含潜变量的 DAG 结构诱导，而只考虑某些类型的约束. 例如，考虑观测变量 $\mathbf{O}$ 上满足同一组条件独立陈述的所有分布（隐含假设 Markov 条件和忠实性），再问如何表示这一条件独立集合.

一种直接做法是假设诱导分布 $P_{\mathbf{O}}$ 相对于无隐藏变量的 DAG 满足 Markov 性与忠实性，再像以前那样输出表示观测分布条件独立性的 DAG 类. 但用 DAG 表示 $P_{\mathbf{O}}$ 的条件独立结构有两个已知缺点：(1) 观测变量上的 DAG 可能导致错误的因果解释；(2) 独立模式与 DAG 的 d 分离陈述对应的分布集合，在边缘化下不封闭［Richardson 与 Spirtes, 2002］.

对于 (1)，考虑诱导分布 $P_{A,B,C,H}$ 相对于图 9.3 左侧对应 DAG 满足 Markov 性与忠实性的 SCM. 观测分布 $P_{A,B,C}$ 中唯一能找到的（条件）独立关系为 $A \perp\!\!\!\perp C$，因此左起第二个 DAG 完全表示这一独立性；在此意义下，可将它看作 PC 的输出. 但其因果解释错误：原 SCM 中干预 C 对 B 毫无影响，PC 的输出却暗示 C 对 B 存在因果效应. 对于 (2)，图 9.4［取自 Richardson 与 Spirtes, 2002］给出变量 $\mathbf{X} = (\mathbf{O}, \mathbf{H})$ 上一

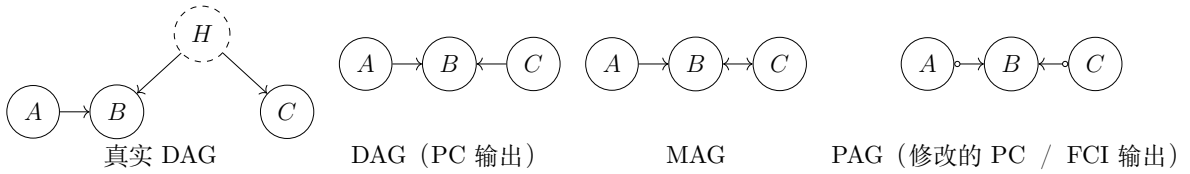


图 9.3: 从左侧 SCM 出发，右侧三个图编码相同的条件独立集合 $A \perp\!\!\!\perp C$. 因为 DAG 会导致错误的因果解释，不宜将它作为因果学习方法的输出. 本例中的 IPG 和潜投影（ADMG）都等于该 MAG.

个 SCM 的结构，其分布相对于 DAG $\mathcal{G}$ 满足 Markov 性和忠实性（$\mathcal{G}$ 表示 $\mathbf{X}$ 中全部条件独立），却不存在 $\mathbf{O}$ 上的 DAG 能表示 $P_{\mathbf{O}}$ 中所有条件独立. 在此意义下，DAG 在边缘化下不封闭.

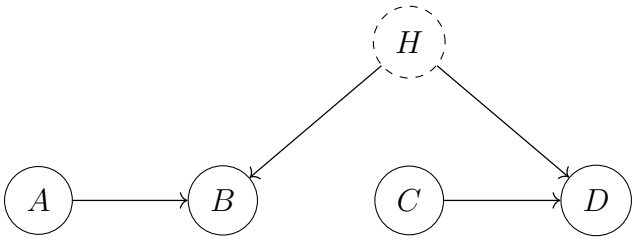


图 9.4: 本例取自 Richardson 与 Spirtes [2002，图 2(i)]. 不存在节点 $\mathbf{O} = \{A, B, C, D\}$ 上的 DAG，能够编码含 H 的图所蕴含的全部条件独立性.

下一小节讨论用 $\mathbf{O}$ 上的图表示条件独立性的一些思路. 但这些图未必具有直观的因果意义；从图形对象推断底层 $\mathbf{X} = (\mathbf{O}, \mathbf{H})$ 上 SCM 的结构性质可能很困难. 例如，第 6.6 节那样的调整图形判据，必须针对每一类图重新提出并证明.

9.4.1 图

此前用图表示 SCM 的结构关系，见定义 3.1 和 6.2. 本节目标不同：用图表示 SCM 所诱导分布中的约束. 本节主要讨论条件独立关系，第 9.5 节再详细讨论其他约束. 隐藏变量使 DAG 不适于表示条件独立，这推动了新的因果推断图形表示的发展. 例如，Richardson 与 Spirtes [2002] 引入极大祖先图（maximal ancestral graph，MAG），并证明它们构成边缘化下封闭的、包含 DAG 的最小图类（见前面的讨论）. 这些混合图包含有向边和双向边.[2] MAG 使用稍有不同的分离判据：不再考虑 d 分离，而考虑 m 分离［Richardson 与 Spirtes, 2002］. 对每个含隐藏变量的 DAG，观测变量上都有唯一的 MAG，通过 m 分离表示相同的条件独立集合；Richardson 与 Spirtes [2002，第 4.2.1 节] 给出简单的构造方法，例子见图 9.3. 这一映射并非一一对应：每个 MAG 都可由无限多个不同 DAG 构造出来，隐藏变量数可任意多. 与 DAG 类似，Markov 条件把 MAG 中的图形分离陈述与条件独立联系起来. 表示相同 m 分离集合的不同 MAG 归入一个 Markov 等价类［Zhang, 2008b］，该等价类本身常用部分祖先图（partially ancestral graph，PAG）表示，概览见表 9.1. PAG 的边可以以圆圈结尾，表示箭头头

[2]事实上，它们还可以包含无向边，因而能够建模选择偏差；细节见 Richardson 与 Spirtes [2002].

部和尾部两种可能，见图 9.3. Ali 等 [2009] 给出判断两个 MAG 是否 Markov 等价的图形判据.

例 9.5（Y 结构） 一个 MAG 就能表示任意多隐藏变量，因而可能令人怀疑：由含隐藏变量 DAG 构造的 PAG，究竟能否包含非平凡的因果信息？例如图 9.3 的 PAG 无法说明 C, B 之间究竟存在有向路径，还是有隐藏变量通过有向路径同时指向二者. 图 9.2 右侧给出 Y 结构（Z_1, Z_2, Y 之间不直接相连）. 现在考虑任意多变量上的一个 SCM，其中四个变量 X, Z_1, Z_2, Y 上的条件独立关系与 Y 结构相同. 则可断言，对应 PAG 包含有向边 $X \to Y$；而且 X, Y 的因果关系必须无混杂［例如 Mani 等, 2006；Spirtes 等, 2000，图 7.23］. 任何 X, Y 受混杂或 X 不是 Y 祖先的 SCM，都会产生不同的条件独立集合. 译注：本段沿用本节开头隐含的 *Markov* 条件与忠实性；只匹配独立关系而不加这些假设，不足以排除因参数抵消产生的额外独立性.

MAG 等图形对象主要用于表示条件独立性，而非像定义 3.1 中那样可视化 SCM，因此因果语义更复杂. 例如 MAG 中的 $A \to B$ 表示：在包含隐藏变量的底层 DAG 中，A 是 B 的祖先，B 不是 A 的祖先，即祖先关系得到保留. 图 9.3 的 PAG 应解释为："底层 DAG 中可能存在从 C 到 B 的有向路径、隐藏共同原因，或两者兼有." 因此，在这些图中做因果推理，即计算干预分布，也更加复杂［例如 Spirtes 等, 2000；Zhang, 2008b］. Perković 等 [2015] 刻画了不仅适用于 DAG、也适用于 MAG 的有效调整集（第 6.6 节）.

MAG、PAG 的另一种替代是诱导路径图（induced path graph，IPG），以及用于表示 IPG 集合的（完备）部分定向诱导路径图（POIPG）［Spirtes 等, 2000，第 6.6 节］. 这些图最初用于表示快速因果推断（FCI）算法的输出，见第 9.4.2 节. 设分布相对于某个 MAG 满足 Markov 性与忠实性. 由于每个 MAG 都是 IPG，而逆命题不成立，该 MAG 的 Markov 等价类包含于相应 IPG 的 Markov 等价类中；所以 PAG 通常比 POIPG 包含更多因果信息［Zhang, 2008b，附录 A］.

还可从含隐藏变量的原 DAG 出发，施行*潜投影*（latent projection）［分别见 Pearl, 2009，定义 2.6.1 和 Verma 与 Pearl, 1991，"嵌入模式"］. 该运算由含观测和隐藏变量的图 $\mathcal{G}$ 构造观测变量上的新图形对象 $\widetilde{\mathcal{G}}$；精确定义例如见 Shpitser 等 [2014，定义 4]. 所得结构称为*无环有向混合图*（acyclic directed mixed graph，ADMG），包含有向边和双向边. 同样，m 分离导出一种 Markov 性质［Richardson, 2003］. 于是可在 ADMG 上而非含潜变量 DAG 上搜索.

第 9.5 节将看到，含潜变量 DAG 在观测变量上诱导的分布还满足条件独立之外的约束. ADMG 可通过如下方式纳入其中一些约束：定义*嵌套 Markov 性质*（nested Markov property）［Richardson 等, 2012, 2017；Shpitser 等, 2014］，使分布相对于 ADMG 满足嵌套 Markov 性，当且仅当它不仅满足图结构蕴含的某些条件独立，还满足其他约束，例见第 9.5.1 节. 即便嵌套 Markov 性也不能编码全部约束（不过在离散情形，它们确实编码全部等式约束［Evans, 2015］）. 因此有［Shpitser 等, 2014］

$$
\begin{aligned}
&\{P_{\mathbf{O}} : P_{\mathbf{O},\mathbf{V}} \text{ 由含潜变量的 DAG } \mathcal{G} \text{ 诱导}\} \\
&\quad \subseteq \{P_{\mathbf{O}} : P_{\mathbf{O}} \text{ 相对于对应 ADMG 满足嵌套 Markov 性}\} \\
&\quad \subseteq \{P_{\mathbf{O}} : P_{\mathbf{O}} \text{ 相对于对应 ADMG 满足 Markov 性}\}.
\end{aligned}
$$

译注：上式源文同样使用下标 $\mathbf{V}$；沿用原符号. 对离散数据及普通 Markov 性质，Evans

与 Richardson [2014] 给出 ADMG 的参数化. 该参数化可扩展到嵌套 Markov 模型，并用于计算（受约束的）极大似然估计量 [Shpitser 等, 2012]. 若任意一对节点间只有一种边，称 ADMG 无弓（bow-free）. 在线性高斯模型中，这个子类允许参数可识别 [Brito 与 Pearl, 2002a]；另外还有计算极大似然估计 [Drton 等, 2009a] 或进行因果学习 [Nowzohour 等, 2015] 的算法.

链图（chain graph）含有向边和无向边，不允许部分有向环 [Lauritzen, 1996, 第 2.1.1 节]. 链图已有大量研究，综述例如见 Lauritzen [1996]，因果解释见 Lauritzen 与 Richardson [2002]. 注意，人们对链图提出了不同的 Markov 性质 [Lauritzen 与 Wermuth, 1989; Frydenberg, 1990; Andersson 等, 2001].

总之，特别在有隐藏变量时，用图表示约束（目前主要谈条件独立）是非平凡且仍活跃的研究问题；Sadeghi 与 Lauritzen [2014] 联系了若干混合图并讨论其 Markov 性质. 图形对象及其分离判据通常很复杂，将边与因果效应的存在联系起来并不容易（不过也可以认为嵌套 Markov 模型向简化迈出了一步）. 尽管困难重重，有些情况下仍可学习因果祖先关系，如例 9.5 的 Y 结构，这令人惊讶.

9.4.2 快速因果推断

对于结构学习，PAG 可能比 CPDAG 更适合作为输出. 的确，可修改 PC 算法使其输出 PAG [Spirtes 等, 2000, 第 6.2 节]. 这种简单修改对许多例子有效，但一般并不正确. PC 每轮考虑一对当前相邻节点 A, B，搜索将它们 d 分离的集合. 为显著加速，它利用第 7.2.1 节引理 7.8(ii)，只搜索 A, B 当前邻居集合的子集. 然而有隐藏变量时，这种限制不再充分 [Verma 与 Pearl, 1991, 引理 3]；Spirtes 等 [2000, 第 6.3 节] 给出修改 PC 无法找到 d 分离集的例子.

FCI 算法 [Spirtes 等, 2000] 解决这一问题，输出表示多个 MAG 的 PAG. Zhang 与 Spirtes [2005] 和 Zhang [2008a] 证明，对原 FCI 作小修改即可得到完备算法，即其输出信息达到最大. 如果条件独立来自含隐藏变量的 DAG，输出确实表示正确的对应 PAG.

FCI 的若干修改可显著加速. Spirtes [2001] 建议限制条件集大小（anytime FCI），Colombo 等 [2012] 则同时减少条件独立检验次数和条件集大小（really fast causal inference）. 两者的信息量都可能略少于 FCI. 后续的 FCI+ 则兼具快速性与完备性 [Claassen 等, 2013].

另一条路线是对 MAG 或其等价类评分. 此类评分函数只对某些 SCM 类存在，如线性 SCM [Richardson 与 Spirtes, 2002]；而且据我们所知，目前还没有有效搜索 MAG 空间的方法 [Mani 等, 2006]. Silva 与 Ghahramani [2009] 讨论了学习混合图的 Bayesian 方法.

9.5 条件独立之外的约束

含隐藏变量的模型可能产生不同于条件独立的约束. 这里举出几类，帮助读者直观了解可以期待哪些约束；细节主要参见文献. 近期工作及较早研究的参考文献还可见 Kela 等 [2017].

9.5.1 Verma 约束

Verma 与 Pearl [1991] 给出图 9.5 的例子. 相对于对应图满足 Markov 性的任何分布，都满足以下 Verma 约束［例如 Spirtes 等, 2000，第 6.9 节］：存在某个函数 f，使

$$\sum_b p(b \mid a)p(d \mid a, b, c) = f(c, d). \tag{9.3}$$

与条件独立约束不同，式 (9.3) 使我们能判断 A 到 D 是否有有向边（注意，图 9.5 中 A, D 无法被 d 分离）. 关于这些代数约束仍有许多开放问题，但对其出现条件的理解已有进展［Tian 与 Pearl, 2002］. Shpitser 与 Pearl [2008b] 研究了特殊子类“休眠独立性”：它们在干预分布中表现为独立约束.

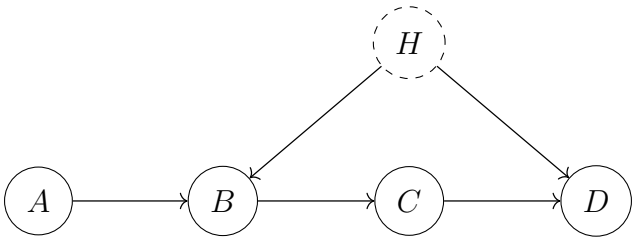


图 9.5: 相对于此图满足 Markov 性的任何分布，都满足 Verma 约束 (9.3)，即出现在 A, B, C, D 边缘分布中的一种非独立性约束. 虚线变量 H 未被观测［Verma 与 Pearl, 1991］.

如何利用这些约束进行因果学习，仍是问题. 例如，对二元变量，Richardson 等 [2012, 2017] 和 Shpitser 等 [2012] 用嵌套 Markov 模型对这类模型参数化，并给出计算（受约束的）极大似然估计量的方法，另见第 9.4.1 节. 但嵌套 Markov 模型不包含全部不等式约束，下一小节讨论这些约束.

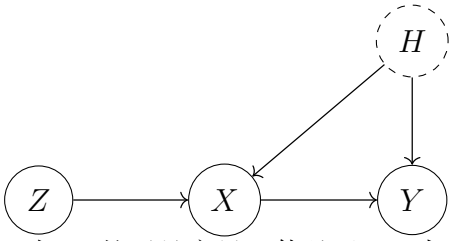
9.5.2 不等式约束

将图模型中的一些变量边缘化，会诱导大量不等式约束［例如 Kang 与 Tian, 2006; Evans, 2012 及其中参考文献］. 列举全部已知约束超出了本书范围. 我们转而说明它们应用领域的多样性，考虑出现在完全不同背景中的两个含观测与未观测变量的 DAG. 本节只讨论涉及可观测变量观测分布的不等式；文献中还有联系可观测变量观测分布与干预分布的不等式［例如 Balke, 1995; Pearl, 2009，第 8 章］，有时附加其他假设［Silva 与 Evans, 2014; Geiger 等, 2014］. 前者旨在证伪假设的潜结构，后者则在相应 DAG 为真的前提下，对干预作出陈述. 只涉及观测概率的不等式，例如图 9.6(a) 的二元变量因果结构蕴含

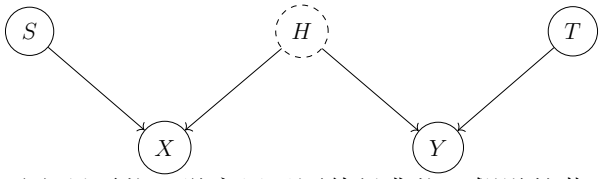
$$P(X = 0, Y = 0 \mid Z = 0) + P(X = 1, Y = 1 \mid Z = 1) \leq 1. \tag{9.4}$$

译注：上式忠实保留源书式 *(9.4)*，但该字面不等式一般不成立. 在相同图类内取 $X := Z, Y := X$（H 可不起作用），两项均为 *1*，左侧为 *2*. 因而不能将此印式直接用作有效的工具变量检验；此处未猜改原作者意图.

这类不等式已见于文献［Bonet, 2001，式 (3)］，用于检验某变量是否为工具变量. 此 DAG 在分析不完全依从的随机临床试验时至关重要：Z 指示服药要求，X 描述患者是否服药（例如假定可用血液检测判断），Y 描述患者是否康复［例如 Pearl, 2009］.



(a) Z 为 X 的工具变量，使关于 X 对 Y 效应的某些因果陈述成为可能.



(b) 量子物理学家用于证伪经典物理假设的著名实验的因果结构，见本小节.

图 9.6: 蕴含不等式约束的两个重要潜结构例子.

图 9.6(b) 的结构例如蕴含 Clauser–Horne–Shimony–Holt (CHSH) 不等式［Clauser 等, 1969］：当 X, Y, S, T 取值于 $\{-1, 1\}$ 时，

$$\begin{aligned} &E[XY \mid S=-1, T=-1] + E[XY \mid S=-1, T=1] \\ &\quad + E[XY \mid S=1, T=-1] + E[XY \mid S=1, T=1] \le 2. \end{aligned} \tag{9.5}$$

译注：源书式 *(9.5)* 四项均印为加号，此处照录. 按字面取 $X=Y=1$，左侧即为 *4*，所以该印式不是一般有效的经典 *CHSH* 界. 通常的 *CHSH* 组合含一个负号；这里不静默替换源式，后文所述实验解释应针对有效的 *CHSH* 组合理解. 式 (9.5) 是 Bell 不等式［Bell, 1964］的推广. 潜在共同原因可取任意多值，因为只要有变量将 $\{X, S\}$ 与 $\{Y, T\}$ d 分离，便蕴含式 (9.5). 值得注意的是，在直觉上会同意底层结构为图 9.6(b) 的量子物理场景中，CHSH 不等式被违反. 位于不同地点的物理学家 A、B 接收来自共同源 H 的粒子. X, Y 分别描述 A、B 对粒子进行二值测量的结果. S 是一次抛硬币，决定 A 在两种可能测量中选哪一种；T 同样决定 B 的测量. X, Y 的未观测共同原因是 A、B 所接收粒子的共同源. 按一种广泛接受的解释，实验中观察到的违反［Aspect 等, 1981］表明：不存在描述入射粒子联合状态的经典随机变量 H，使给定 H 时 $\{S, X\}$ 与 $\{T, Y\}$ 条件独立. 原因在于量子物理系统的状态不能由随机变量的值描述，而应由 Hilbert 空间上的密度算子描述.

潜结构的信息论不等式日益受到关注，因为有时比直接涉及概率的不等式更易处理［例如 Steudel 与 Ay, 2015］. Chaves 等 [2014] 描述了离散变量情形下一族并不完备、但可按以下系统方法生成的不等式.

首先从 d 个离散变量 $\mathbf{X} := (X_1, \ldots, X_d)$ 上 SCM 所诱导的分布出发. 给定联合分布 $P_{X_1,\ldots,X_d}$，可定义函数

$$H : 2^{\mathbf{X}} \longrightarrow \mathbb{R}_0^+,$$

使 $H(X_{j_1},\dots,X_{j_k})$ 为 $(X_{j_1},\dots,X_{j_k})$ 的 Shannon 熵.[3] H 的熟知基本性质为

$$H(\mathbf{S}\cup\{X_j\}) \geq H(\mathbf{S}), \tag{9.6}$$

$$H(\mathbf{S}\cup\{X_j,X_k\}) \leq H(\mathbf{S}\cup\{X_j\}) + H(\mathbf{S}\cup\{X_k\}), \tag{9.7}$$

$$H(\varnothing) = 0, \tag{9.8}$$

其中 $\mathbf{S}$ 是 $\mathbf{X}$ 的子集. 式 (9.6) 和 (9.7) 分别称为单调性和次模性条件，另见第 6.10 节. 式 (9.6)–(9.8) 在组合优化中也称为多拟阵公理. 译注：源书式 *(9.7)* 右侧未减去 $H(\mathbf{S})$，此处保留印式. 标准次模性条件应为 $H(\mathbf{S}\cup\{X_j,X_k\})+H(\mathbf{S}) \leq H(\mathbf{S}\cup\{X_j\})+H(\mathbf{S}\cup\{X_k\})$. 源式是由该条件和非负性推出的较弱不等式，不能直接代替完整次模公理. 对无限取值变量，还须注意熵是否有限.

为利用因果结构，回顾：若三个互不相交节点子集 $\mathbf{S},\mathbf{T},\mathbf{R}$ 中，$\mathbf{R}$ 将 $\mathbf{S},\mathbf{T}$ d 分离，则 $\mathbf{S} \perp\!\!\!\perp \mathbf{T} \mid \mathbf{R}$. 用 Shannon 互信息 [Cover 与 Thomas, 1991] 可改写为

$$I(\mathbf{S}:\mathbf{T}\mid\mathbf{R}) = 0, \tag{9.9}$$

等价地，

$$H(\mathbf{S}\cup\mathbf{R}) + H(\mathbf{T}\cup\mathbf{R}) = H(\mathbf{S}\cup\mathbf{T}\cup\mathbf{R}) + H(\mathbf{R}). \tag{9.10}$$

值得注意的是，式 (9.10) 为线性方程. 条件独立在概率向量空间中定义非线性约束，因此转向熵向量空间考虑约束更为方便.

这些基本不等式与式 (9.9) 一起蕴含更多不等式. 为以算法方式导出它们，Chaves 等 [2014] 使用线性规划技术 Fourier–Motzkin 消元 [Williams, 1986]. 给定观测变量子集 $\mathbf{O}\subset\mathbf{X}$，该过程常可导出只含 $\mathbf{O}$ 中变量熵的不等式，即使不存在只含观测变量的条件独立约束. 图 9.7 是一例，Chaves 等 [2014，定理 1] 得到

$$I(X:Z) + I(Y:Z) \leq H(Z), \tag{9.11}$$

以及变量名循环置换得到的对应不等式. 违反此式的一个联合分布是：全部观测变量同时为 0 或同时为 1，各以概率 1/2 发生. 此时 $H(Z)=1$ bit，而 $I(X:Z)=I(Y:Z)=1$ bit. 直观上，本例要求每个观测节点（如 Z）与 X,Y 都有确定关系，从而也与 U,V 有确定关系. 但 Z 能在多大程度上由其未观测原因 U 或 V 决定，存在权衡：Z 无法同时完美遵循彼此独立的 U,V 的“指令”.

9.5.3 基于协方差的约束

含隐藏变量的线性模型会产生另一类约束. 例如，图 9.8 中得到四分差约束 [Spirtes 等, 2000；Spearman, 1904]：

$$\rho_{AC}\rho_{BD} - \rho_{AD}\rho_{BC} = 0, \tag{9.12}$$

$$\rho_{AB}\rho_{CD} - \rho_{AD}\rho_{BC} = 0, \tag{9.13}$$

$$\rho_{AC}\rho_{BD} - \rho_{AB}\rho_{CD} = 0, \tag{9.14}$$

[3] 为记号方便，写 $H(X_{j_1},\dots,X_{j_k})$ 而非 $H((X_{j_1},\dots,X_{j_k}))$，并再次对向量使用集合运算.

图形对象	DAG（无隐藏变量）	MAG	IPG	ADMG（嵌套 Markov）
边类型：有向 / 无向 / 双向 / 组合	是 / 否 / 否 / 否	是 / 是 / 是 / 否	是 / 否 / 是 / 否	是 / 否 / 是 / 是
正确的因果解释	否	是	是	是
全局 Markov 性的图形分离	d 分离	m 分离	m 分离	m 分离
有效调整集判据	是	是	?	是
干预分布识别算法	是	?	?	是
等价类表示	CPDAG（Markov）	PAG（Markov）	POIPG（Markov）	?（嵌套 Markov）
基于独立性的学习方法	PC、IC、SGS	FCI	FCI	无
基于评分的学习方法	GDS、GES	线性 / 二元 / 离散 SCM	?	二元 / 离散 SCM
能编码全部等式约束	否	否	否	是（观测变量离散时）
能编码全部约束	否	否	否	否

表 9.1: 考虑观测变量 $\mathbf{O}$ 与隐藏变量 $\mathbf{H}$ 上的 SCM，诱导分布 $P_{\mathbf{O},\mathbf{V}}$. 如何建模观测分布 $P_{\mathbf{O}}$? 本希望使用含任意多潜变量的 SCM，但该模型类对因果学习具有不良性质. 此表汇总替代模型类；当前研究尤其关注 MAG 和 ADMG. 译注：源图注将隐藏变量先写作 $\mathbf{H}$，分布下标却写 $\mathbf{V}$；此处照录. 表中 “正确的因果解释” 针对含隐藏变量时直接使用相应表示的情形，不能理解为所有无隐藏变量 DAG 都没有因果解释.

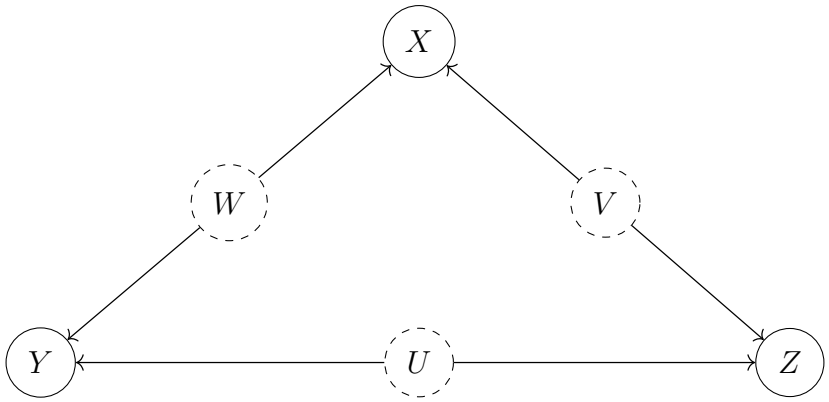


图 9.7: 此 DAG 无法生成这样的 X, Y, Z 联合分布：三个观测变量以概率 1/2 同时为 0，以概率 1/2 同时为 1.

其中 ρ_{AC} 为 A, C 的相关系数. 例如，第一条约束可从图 9.8 轻易验证：

$$\begin{aligned}\operatorname{cov}[A,C]\operatorname{cov}[B,D] &= \alpha\gamma\eta\operatorname{var}[H]\cdot\beta\delta\eta\operatorname{var}[H]\\ &= \alpha\delta\eta\operatorname{var}[H]\cdot\beta\gamma\eta\operatorname{var}[H] = \operatorname{cov}[A,D]\operatorname{cov}[B,C].\end{aligned}$$

译注：三条等式均按源书保留，但图中一般只保证第一条. 若 $J := \eta H + N_J$，且各外生噪声独立，则第二条对应的协方差乘积差为 $\alpha\beta\gamma\delta\operatorname{var}[H]\operatorname{var}[N_J]$，一般非零；第三条为其相反数. 相关系数形式在方差非零时仅再除以公共标准差乘积. 因而后两条还需额外条件，不能由所示图单独推出.

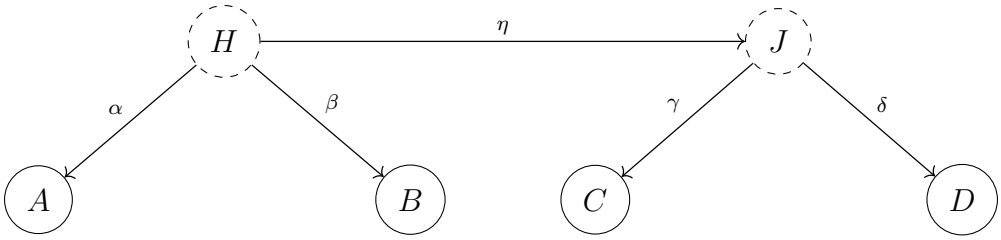


图 9.8: 若此图对应线性 SCM，源书称其诱导分布满足四分差约束 (9.12)–(9.14)；后两条的适用条件见相邻译注.

可用 trek 和 choke point 的语言，从图上刻画四分差约束何时为零 [Spirtes 等, 2000，定理 6.10]. 同样，这些约束使我们仅凭观测数据就能区分不同因果结构. Bollen [1989] 和 Wishart [1928] 构造了检验四分差是否为零的统计检验；可将其转为因果学习评分，例如 Spirtes 等 [2000，第 11.2 节] 和 Silva 等 [2006] 对此进行了研究.

Kela 等 [2017] 考虑观测变量间全部依赖均由一组独立共同原因引起的潜结构，描述观测变量协方差矩阵可能满足的约束. 他们强调，与完整分布相比，使用协方差矩阵在统计可行性和计算可处理性上均有优势. 对观测变量使用函数，即像再生核 Hilbert 空间方法那样映射至特征空间，还可纳入高阶依赖.

9.5.4 加性噪声模型

第 7.2.3 节提到，LiNGAM 的结构学习可基于 ICA. Hoyer 等 [2008b] 利用所谓超完备 ICA，将可识别性陈述和方法推广到含隐藏变量的线性非高斯结构.

对非线性 ANM（第 4.1.4 节），我们已看到，一般情形下不可能同时有 $Y = f(X) + N_Y$、$N_Y \perp\!\!\!\perp X$，以及 $X = g(Y) + M_X$、$M_X \perp\!\!\!\perp Y$. 预期隐藏变量也具有类似可识别性. 以下 ANM 描述隐藏变量 H 对观测量 X, Y 的影响：

$$H := N_H, \tag{9.15}$$

$$X := f(H) + N_X, \tag{9.16}$$

$$Y := g(H) + N_Y. \tag{9.17}$$

在噪声充分小的范围内，Janzing 等 [2009a] 证明，可从 $P_{X,Y}$ 重建 $P_{H,X,Y}$，至多相差 H 的重参数化. 低噪声限制可能并非必要，而只是证明的弱点. 取 $f(H) = H, N_X = 0$ 就得到 X 到 Y 的 ANM（同样可得到 Y 到 X 的 ANM）；这暗示加性噪声假设可能仅由

$P_{X,Y}$ 就使 $X \to Y$、$X \leftarrow Y$、$X \leftarrow * \to Y$ 三种情形可区分. 与降维的联系帮助理解如何从数据拟合式 (9.15)–(9.17)：可按以下步骤从 $P_{X,Y}$ 生成数据点 (x, y)，见图 9.9.

1. 按 P_H 抽取 h.
2. 考虑流形上相应的点 $(f(h), g(h))$：

$$\mathcal{M} := \{(f(h), g(h)) \in \mathbb{R}^2 : h \in \mathbb{R}\}. \tag{9.18}$$

3. 在每个维度添加一些独立噪声 (n_X, n_Y).

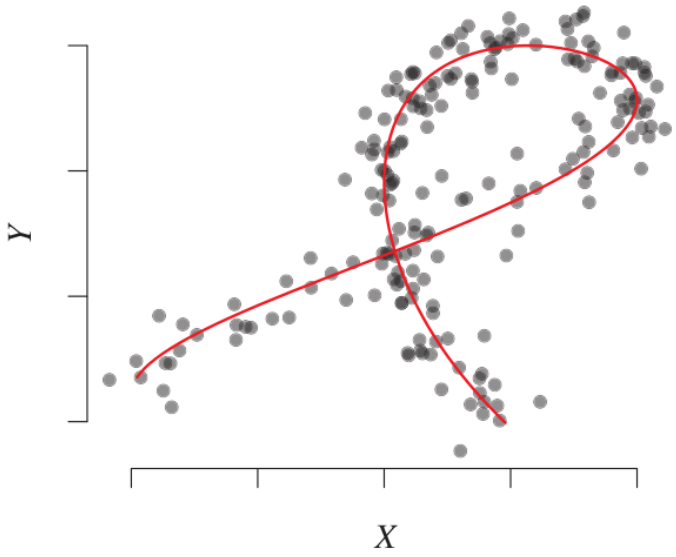


图 9.9: $P_{X,Y}$ 的散点图；红线描述式 (9.18) 的流形 $\mathcal{M}$.

因此，为由 $P_{X,Y}$ 的样本拟合该模型，可对样本使用降维技术，得到估计 $\widehat{\mathcal{M}}$. 为从给定点 (x, y) 恢复相应 h，不应将点投影到流形 $\mathcal{M}$ 上，因为这样通常会使残差依赖 H. 我们要求的并非残差 (n_X, n_Y) 小，而是它们尽可能与 H 独立 [Janzing 等, 2009a] .

含隐藏变量 ANM 的可识别性仍有许多开放问题. 但此类结果可能有重要含义：每当发现 X 到 Y 存在 ANM、而反向不存在时，这些可识别性结果就可表明该效应（在加性噪声模型类内）无混杂.

9.5.5 检测低复杂度混杂因素

这里介绍 Janzing 等 [2011] 的两种方法，推断两个观测变量 X, Y 之间的路径是否经过某个仅取少数值的变量，见图 9.10. 设置如下：X 经一个在 Y 处有箭头头部的 DAG 与 Y 因果相连，问题是该路径是否经过仅取少数值的 U. 连接 X, U 的箭头方向在这里无关紧要；典型应用是在混杂路径经过这种简单 U 时检测混杂. 例如，Janzing 等 [2011] 考虑描述动植物遗传变体（单核苷酸多态性）的两个二元变量 X, U，以及对应某种表型的变量 Y. 如果 X, Y 间的统计依赖完全来自 U 影响 Y 且 U 与 X 统计相



图 9.10: 检测低复杂度中间变量：若某个仅取少数值的 U 阻断 X, Y 之间的路径，则 $P_{Y|X}$ 常呈现特征性质，作为 U 的“指纹”.

关，那么 U 就起这种中间变量的作用. 此处 U, X 互不为因，但“族群”等变量影响二者；所以 U 本身并非共同原因，而是位于混杂路径上.

检测这类混杂的思路是，U 会以特征方式改变条件分布 $P_{Y|X}$. 先定义一类条件分布，稍后将说明它通常只在 X, Y 路径不经过这种 U 时出现.

定义 9.6（两两纯条件分布） 若对任意两个 $x_1, x_2 \in \mathcal{X}$，都不存在 $\lambda < 0$ 或 $\lambda > 1$ 使

$$\lambda P_{Y|X=x_1} + (1-\lambda) P_{Y|X=x_2} \tag{9.19}$$

为概率分布，则称 $P_{Y|X}$ 两两纯. 译注：源定义未显式写 $x_1 \neq x_2$；若允许二者相等，式 (9.19) 对任意 λ 都是同一概率分布，没有条件分布能满足定义. 后续两两纯性的非平凡讨论须针对不同的条件值理解，此处保留原定义措辞并指出这一边界.

当 $\lambda \in [0,1]$ 时，式 (9.19) 总是概率分布，因为它是两个分布的凸组合. 当 $\lambda \notin [0,1]$ 时，它可能不再是非负测度. 设 Y 只取有限多个值 $\mathcal{Y} := \{y_1, \ldots, y_k\}$，则 Y 的分布空间为单纯形，其 k 个顶点是 $y_1, \ldots, y_k$ 上的点质量. 图 9.11 展示 $k = 3$ 的情形，此时分布空间为三角形. 图 (a) 中，延长连接 $P_{Y|X=x_1}, P_{Y|X=x_2}$ 的线就会离开三角形，是纯条件分布的例子；图 (b) 中则能在分布空间内继续延长. 图 9.12 表明，纯性强于各点 $P_{Y|X=x}$ 位于单纯形内部这一条件：图中两点位于三角形的边上，却仍可在三角形内延长连接线. 译注：前一句沿源文“强于位于内部”照译，但两个图实际说明的是位于边界仍不足以保证纯性；内部点本身也不能满足所述不可延长性质. 源文比较方向存在歧义，不据此建立额外蕴含.

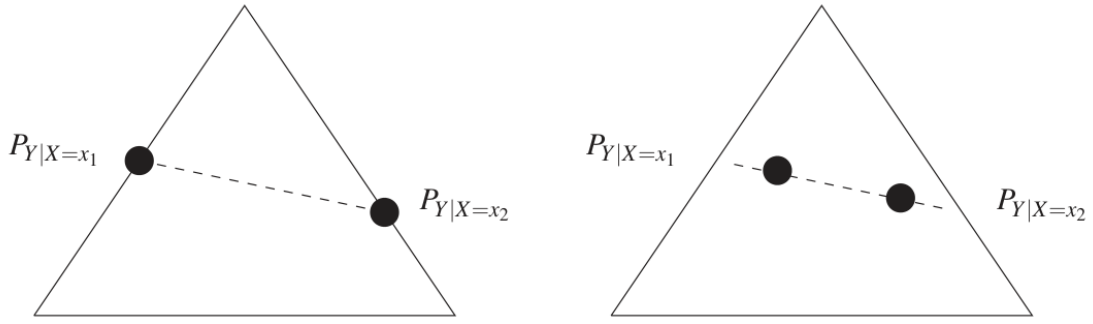


图 9.11: 纯与非纯条件分布的可视化. (a) 纯条件分布：连接两条件分布的线一经延长就离开概率分布单纯形. (b) 非纯条件分布：连接线可略微延长而不离开单纯形.

若 $P_{Y|X}$ 有密度 $(x, y) \mapsto p(y \mid x)$，纯性可用以下直观条件定义：

$$\inf_{y \in \mathcal{Y}} \frac{p(y \mid x_1)}{p(y \mid x_2)} = 0 \qquad \forall x_1, x_2 \in \mathcal{X}.$$

译注：仍须注意不同条件值以及分母为零处的比值定义；源式未给这些边界约定. 自然界中 $X \to Y$ 对应的因果条件分布有多大程度满足纯性，还需未来研究. 一个有趣的纯

条件分布类是：若 $P_{Y|X}$ 允许具有双射函数 f_Y 的 ANM [Janzing 等, 2011, 引理 4]，且噪声密度满足某个衰减条件，则它两两纯.

以下结果表明，纯条件分布强烈暗示 X, Y 因果路径不经过仅取少数值的变量. **定理 9.7（严格为正的条件分布与非纯性）** 假设存在 U 使 $X \perp\!\!\!\perp Y \mid U$，其值域 $\mathcal{U}$ 有限，并且对全部 $u \in \mathcal{U}$ 及使 $P_{Y|X=x}$ 有定义的所有 x，条件密度 $p(u \mid x)$ 严格为正. 则 $P_{Y|X}$ 不两两纯.

证明： 容易看出，$P_{U|X}$ 不两两纯，因为对使 $P_{Y|X=x_i}$ 有定义的全部 x_1, x_2，有 $\inf_{u\in\mathcal{U}} p(u \mid x_1)/p(u \mid x_2) \neq 0$. 由 $p(y \mid x) = \sum_u p(y \mid u)p(u \mid x)$，$P_{Y|X}$ 是 $P_{Y|U}$ 与 $P_{U|X}$ 的串接，所以也因 $P_{U|X}$ 不纯而不纯 [见 Janzing 等, 2011, 引理 8]. □

虽然定理对所有有限变量成立，但当 U 仅取少数值时，条件分布 $P_{U|X}$ 严格为正的第二个假设可信得多. 否则可能存在某些 u 使 $p(u \mid x)$ 极接近 0，从而使 $P_{Y|X}$ 近乎纯.

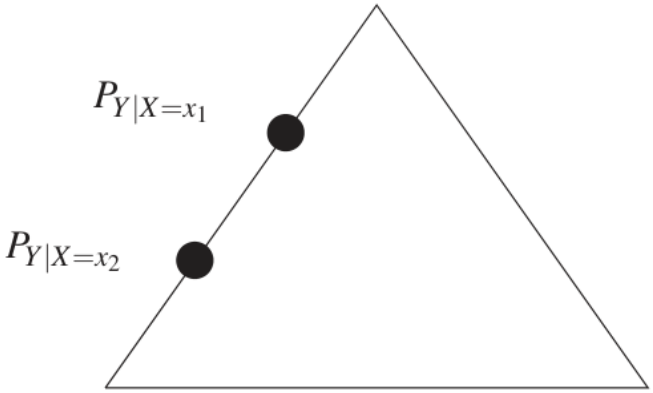


图 9.12: 非纯条件分布的另一例子：连接 $P_{Y|X=x_1}$ 和 $P_{Y|X=x_2}$ 的线可以延长而不离开单纯形.

一个说明中间节点如何破坏纯性的例子是：设 U, X 为二元变量，且当 $u = x$ 时 $p(u \mid x) = 1 - \varepsilon$，则

$$\begin{aligned} P_{Y|X=0} &= P(U = 0 \mid X = 0)P_{Y|U=0} + P(U = 1 \mid X = 0)P_{Y|U=1} \\ &= (1 - \varepsilon)P_{Y|U=0} + \varepsilon P_{Y|U=1}. \end{aligned}$$

因此 $P_{Y|X=0}$ 位于连接 $P_{Y|U=0}, P_{Y|U=1}$ 的线段内部（$P_{Y|X=1}$ 亦然），所以 $P_{Y|X}$ 不纯. 译注：关于线段内部的陈述需要 $0 < \varepsilon < 1$；端点情形不由这个论证覆盖.

中间变量在 $P_{X,Y}$ 中留下特征 “指纹” 的另一例子，可以用以下条件分布性质表述 [Allman 等, 2009; Janzing 等, 2011]. **定义 9.8（条件分布的秩）** $P_{Y|X}$ 的秩，是测度空间中所有向量 $P_{Y|X\in A}$ 张成的向量空间维数，其中 A 遍历 X 值域中概率非零的全部可测子集.

Janzing 等 [2011] 未给出估计秩的算法. 若 Y 的值域有限，$P_{Y|X}$ 定义一个随机矩阵，其秩与 $P_{Y|X}$ 的秩一致. 以下结果是简单的观察 [Allman 等, 2009]. **定理 9.9（秩与 U 的值域）** 若 $X \perp\!\!\!\perp Y \mid U$ 且 U 取 k 个值，则 $P_{Y|X}$ 的秩至多为 k.

容易证明，在此定理条件下，$P_{X,Y}$ 可分解为 k 个乘积分布的混合. 这可推广至多变量情形：若有取 k 个值的 U，使给定 U 时 $X_1, \dots, X_d$ 联合独立，则 $P_{X_1,\dots,X_d}$ 可分解为 d 个乘积分布的混合. 译注：末句源文印为 d 个，按同段构造通常应为至多 k 个分量，每个分量为 d 个单变量分布的乘积；此处保留源文并说明这一区别. Sgouritsa 等 [2013] 和 Levine 等 [2011] 描述了求这种分解的方法，目标是通过识别乘积分布检测 “混杂因素” U.

9.5.6 不同环境

第 7.1.6 和 7.2.5 节的不变因果预测方法可修改以处理隐藏变量 [Peters 等, 2016, 第 5.2 节]，前提是隐藏变量不受干预影响. 此外，Rothenhäusler 等 [2015, “backShift”] 考虑线性 SCM 的特殊情形. 假设在不同环境 $e \in \mathcal{E}$ 观测到 d 维随机向量 $\mathbf{X}^e$. 环境由未知偏移变量 $\mathbf{C}^e = (C_1^e, \dots, C_d^e)$ 产生，要求各分量相互独立，且与噪声变量独立. 对每个环境，

$$\mathbf{X}^e = B\mathbf{X}^e + \mathbf{C}^e + \mathbf{N}^e,$$

其中 $\mathbf{N}^e$ 的分布不依赖 e. 允许噪声不同分量间协方差非零，就可容纳隐藏变量. 仍有

$$(I - B)\Sigma_{X,e}(I - B)^T = \Sigma_{C,e} + \Sigma_N,$$

其中三者分别为 $\mathbf{X}^e, \mathbf{C}^e, \mathbf{N}^e$ 的协方差矩阵. 因此，

$$(I - B)(\Sigma_{X,e} - \Sigma_{X,f})(I - B)^T = \Sigma_{C,e} - \Sigma_{C,f}. \tag{9.20}$$

注意，对每个 e 可合并其他所有环境，得到 “环境” f. 由假设，对所有 e, f，式 (9.20) 右侧均为对角矩阵，故可对 $\Sigma_{X,e} - \Sigma_{X,f}$ 联合对角化，重建因果结构 B. 若至少有三个环境，则在弱假设下可识别 B [Rothenhäusler 等, 2015, 定理 1].

这个例子说明，在不同环境间施加线性模型、独立偏移干预等正则条件，即使有隐藏变量，也可重建底层因果结构.

9.6 习题

问题 9.10（充分性） 证明注 9.4.

问题 9.11 (Simpson 悖论) 构造含二元随机变量 X, Y 及变量序列 $Z_1, Z_2, \dots$ 的 SCM $\mathfrak{C}$，使对所有偶数 $d \geq 0$ 和所有 $z_1, \dots, z_{d+1}$，

$$\begin{aligned} &P^{\mathfrak{C}}(Y = 1 \mid X = 1, Z_1 = z_1, \dots, Z_d = z_d) \\ &\quad > P^{\mathfrak{C}}(Y = 1 \mid X = 0, Z_1 = z_1, \dots, Z_d = z_d), \end{aligned}$$

但

$$\begin{aligned} &P^{\mathfrak{C}}(Y = 1 \mid X = 1, Z_1 = z_1, \dots, Z_d = z_d, Z_{d+1} = z_{d+1}) \\ &\quad < P^{\mathfrak{C}}(Y = 1 \mid X = 0, Z_1 = z_1, \dots, Z_d = z_d, Z_{d+1} = z_{d+1}). \end{aligned}$$

此例把 Simpson 悖论推至极端. 若 X 表示治疗，Y 表示康复，$Z_1, Z_2, \ldots$ 为混杂因素，则按调整公式 (6.13)，对越来越多变量作调整，每次都会反转治疗有益还是有害的因果结论.

问题 9.12（工具变量） 考虑 SCM

$$H := N_H, \qquad Z := N_Z,$$
$$X := f(Z) + g(H) + N_X, \qquad Y := \alpha X + j(H) + N_Y,$$

假设观测到 Z, X, Y 的联合分布. 给定分布而非有限样本，将 X 非参数地对 Z 回归，得到的回归函数是条件均值 $E[X \mid Z = z]$. 写出两阶段最小二乘法，并证明它识别 α. 译注：题目未单独重述工具变量相关性；若 f 为常数、第一阶段拟合值无变异，就不能用此法识别 α. 应结合第 *9.3* 节的相关性条件理解，不将本题视为无条件识别结论.

Chapter 10

时间序列

推断不同时刻变量之间的因果关系，比没有时间结构时容易，因为因果结构必须与时间顺序一致. 第 7.2.4 节已表明，在已知节点因果顺序且无隐藏变量的假设下，寻找因果 DAG 除 Markov 条件与极小性外不需要其他假设，例如更有争议的忠实性或受限函数类. 给定时间顺序，仍有三个主要问题：所考虑变量集合可能不因果充分；在给定测量精度下，可能有属于同一时刻的变量，事先无法确定它们的因果顺序；实践中通常只得到时间序列的一次实现，而不像通常独立同分布设置那样反复观测每个变量. 这些问题都对时间序列的因果推理至关重要.

10.1 预备知识与术语

此前考虑从联合分布 $P_{X_1,\dots,X_d}$ 独立同分布抽样. 这里讨论时间序列因果推断，即有 d 元时间序列 $(\mathbf{X}_t)_{t\in\mathbb{Z}}$，固定 t 时 $\mathbf{X}_t = (X_t^1,\dots,X_t^d)$. 假设它描述严格平稳随机过程 [例如 Brockwell 与 Davis, 1991] . 变量 X_t^j 表示系统第 j 个可观测量在时刻 t 的测量. 由于因果影响不能从未来指向过去，区分多元时间序列中的两类因果关系.

第一，节点为 X_t^j、$(j,t)\in\{1,\dots,d\}\times\mathbb{Z}$ 的因果图[1]只包含 $t<s$ 时从 X_t^j 到 X_s^k 的箭头，而不包含 $t=s$ 时的箭头，见图 10.1. 此时称无瞬时效应（instantaneous effects）. 第二，因果图除了 $t<s$ 时某些 X_t^m 到 X_s^ℓ 的箭头外，还有某些 j,k 对应的 $X_t^j\to X_t^k$，如图 10.2. 若对任意 $j\neq k$ 和 $h>0$，X_t^j 可以影响 X_t^k 和 X_{t+h}^j，但不能影响 X_{t+h}^k，称因果结构纯瞬时，见图 10.5(a)、(b). 若每个 X_t^j 均不受任何过去变量（包括自身过去）影响，就不必用时间序列描述；此时 t 可视为前面独立同分布设置中统计样本独立实例的标号.

全时间图（full time graph）定义为以 X_t^i 为节点的 DAG，如图 10.1 和 10.2. 与前面不同，它含无限多个节点. 汇总图（summary graph）是以 $X^1,\dots,X^d$ 为节点的有向图：当 $j\neq k$ 且某些 $t\le s\in\mathbb{Z}$ 存在 $X_t^j\to X_s^k$ 时，包含 $X^j\to X^k$. 虽然假设全时间图无环，汇总图却可以有环. 图 10.3 是前两图对应的汇总图. 对 $t\in\mathbb{Z}$，$\mathbf{X}_{\mathrm{past}(t)}$ 表示全部 $s<t$ 时的 $\mathbf{X}_s$，$X^j_{\mathrm{past}(t)}$ 表示特定分量 X^j 的过去. 当 t 是固定参照时刻，也写作 $\mathbf{X}_{\mathrm{past}}$. 此外，$(\mathbf{X}_t^{-j})_{t\in\mathbb{Z}}$ 表示所有 $k\neq j$ 的时间序列 $(X_t^k)_{t\in\mathbb{Z}}$ 的集合.

[1]严格地说，此前只对有限多个节点定义因果 DAG；这里需要无限图，暂忽略这一技术细节，见例如 Peters 等 [2013].

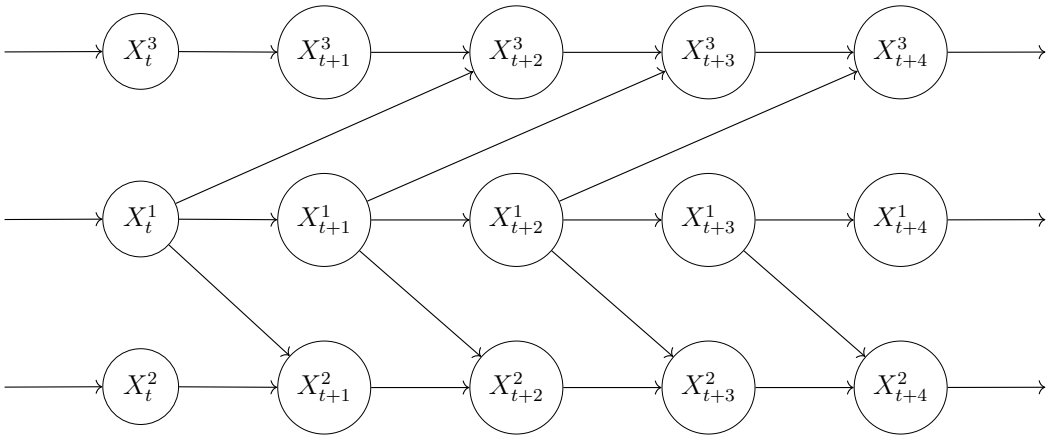


图 10.1: 无瞬时效应的时间序列例子.

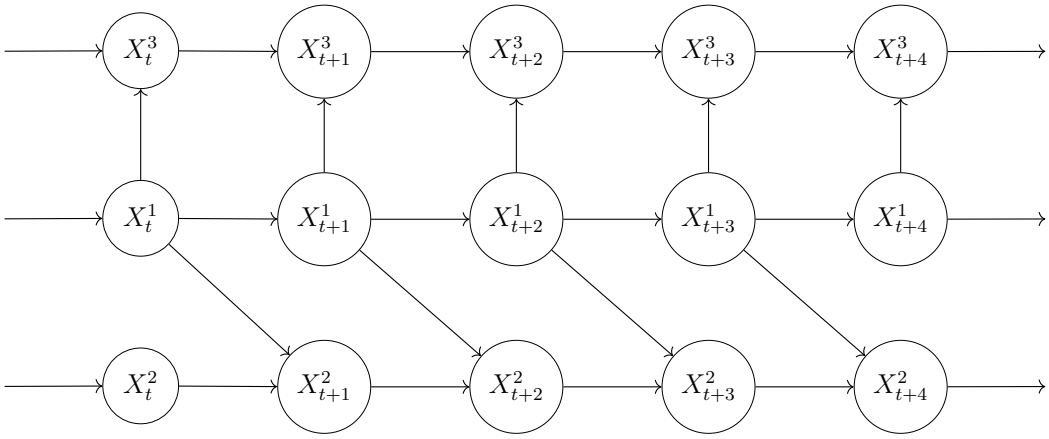


图 10.2: 含瞬时效应的时间序列例子.

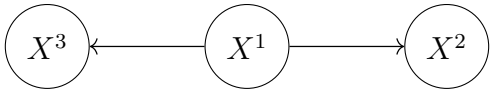


图 10.3: 图 10.1 和 10.2 全时间图对应的汇总图.

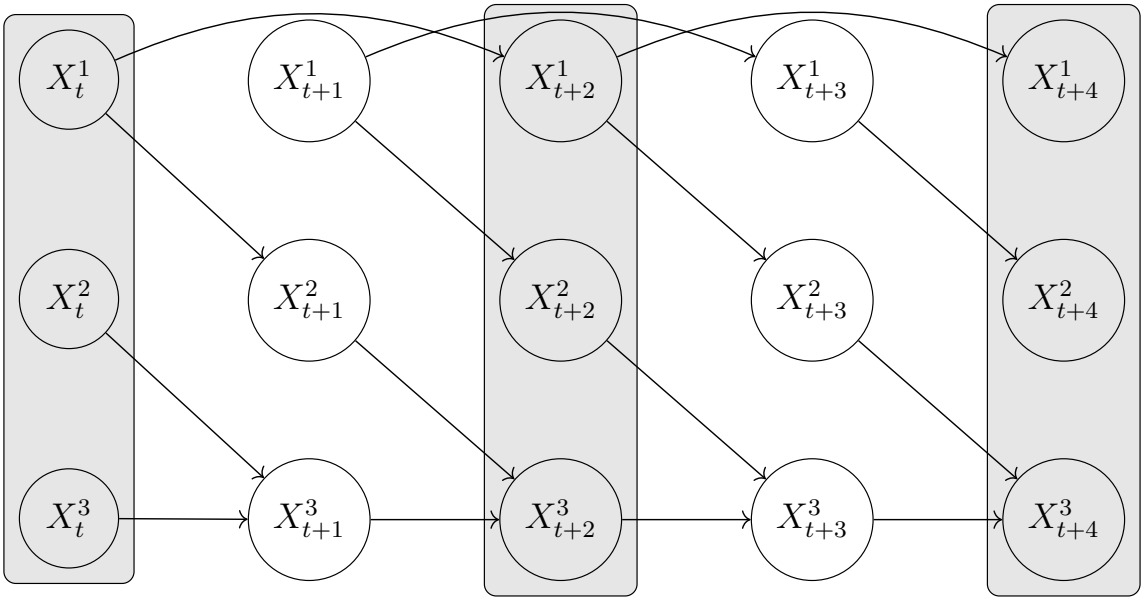


图 10.4: 次采样时间序列的例子：只观测阴影区域内的变量.

10.2 结构因果模型与干预

假设随机过程 $(\mathbf{X}_t)_{t\in\mathbb{Z}}$ 允许如下 SCM 描述：对某个 q，至多涉及所有变量过去 q 个值，

$$X_t^j := f^j\big((\mathbf{PA}_q^j)_{t-q}, \dots, (\mathbf{PA}_1^j)_{t-1}, (\mathbf{PA}_0^j)_t, N_t^j\big), \tag{10.1}$$

其中

$$\dots, N_{t-1}^1, \dots, N_{t-1}^d, N_t^1, \dots, N_t^d, N_{t+1}^1, \dots, N_{t+1}^d, \dots$$

为联合独立的噪声项. 对每个 $s \in \mathbb{Z}$，$(\mathbf{PA}_s^j)_{t-s}$ 表示影响 X_t^j 的变量 X_{t-s}^k $(k = 1, \dots, d)$ 集合. 当 $s > 0$ 时，$\mathbf{PA}_{t-s}^j$ 可包含 X_{t-s}^j，但 $s = 0$ 时不可. 假设对应全时间图无环.

一个常见特例是向量自回归模型（vector autoregressive model，VAR）[Lütkepohl, 2007]：

$$X_t^j := \sum_{i=1}^{q} A_i^j \mathbf{X}_{t-i} + N_t^j, \tag{10.2}$$

其中每个 A_i^j 为 $1 \times d$ 矩阵；另见注 6.5 关于线性循环模型的讨论，尤其式 (6.4).

与独立同分布设置一样，SCM 将干预效应形式化：干预就是替换某些结构赋值. 例如，对某个 j，将全部 $\{X_t^j\}_{t\in\mathbb{Z}}$ 设为特定值；也可仅在某个时刻 t 干预 X_t^j.

10.2.1 次采样

许多应用中，采样可能慢于因果过程的时间尺度. 图 10.4 只观测每隔一个时刻. 原完整系统的汇总图含边 $X^1 \to X^2 \to X^3$. 若希望为观测到的次采样过程建立因果模型，就必须定义允许哪些干预. 第一，若只允许干预观测时刻，则不应有从 X^1 到 X^2 的因

果影响：干预 X^1 的一个观测实例，对 X^2 的可观测部分没有影响（注意 X^1 只有滞后二阶效应 $X^1_t \to X^1_{t+2}$）. 此外，这种设置下，原先没有瞬时效应时，次采样不会凭空产生瞬时效应. 对 SCM，Bongers 等 [2016，第 3 章] 描述了通过将隐藏时步的因果机制代入其他机制，实现模型边缘化的形式化过程. 只要干预限于观测时刻，所得模型就正确描述干预效应. 第二，若也考虑对隐藏变量的干预，则可能希望恢复原汇总图，例如 Danks 与 Plis [2013] 和 Hyttinen 等 [2016] 研究了此问题.

有时次采样并不是数据生成过程的良好模型. 例如很多物理测量可能应建模为连续时刻的平均，而非稀疏选取的时间点. 前者是有用但复杂的模型假设：平均过程可能改变模型类，还必须谨慎定义干预.

10.3 学习因果时间序列模型

Granger 因果及其变体目前是最流行的因果时间序列分析方法之一. 但为更好衔接前面各章，我们先解释基于条件独立的方法可以得出什么结论；这一顺序不代表对方法优劣的判断. 第 10.3.1、10.3.2 节主要给出可识别性结果，接下来的三节给出更具体的学习方法，适用于只在有限多个时刻采样一次的多元时间序列. 不过大部分思路也适用于得到同一时间序列若干独立同分布重复实现的情形.

10.3.1 Markov 条件与忠实性

引理 6.25 指出，两个 DAG Markov 等价，当且仅当它们骨架与 v 结构集合相同. 如果没有瞬时效应，知道骨架就已确定全时间图，因为箭头只能沿时间向前. 因而得到 [Peters 等, 2013，定理 1 的证明]：

定理 10.1（无瞬时效应时的可识别性） 假设两个全时间图由无瞬时效应的 SCM 诱导. 若它们 Markov 等价，则二者相同.

因此，在 Markov 条件与忠实性成立时，可以从条件独立关系唯一识别全时间图（处理无限大 DAG 时，有时假设时间序列从 $t = 0$ 开始）. 有瞬时效应时，Markov 等价图至多在瞬时效应方向上不同. 但很多情况下，这些方向也可识别，因为不同瞬时方向诱导不同 v 结构集合，简单例子见图 10.5. 即便对全部 $t \in \mathbb{Z}$ 给图加上 $X_t \to Y_{t+1}$，仍可推断瞬时效应方向；只加 $Y_t \to X_{t+1}$ 也一样；但不能两类边都加，因为这会移除全部 v 结构. Peters 等 [2013，定理 1] 给出以下充分条件.

定理 10.2（无环汇总图的可识别性） 假设两个全时间图由 SCM 诱导，而且两者中对每个 j，都存在 $s \geq 1$ 使 X^j_t 受 X^j_{t-s} 影响. 进一步假设汇总图无环. 若全时间图 Markov 等价，则它们相同.

以下结果表明，原则上只需一次条件独立检验，就能判断汇总图中任一箭头是否存在. **定理 10.3（Granger 因果的依据）** 考虑时间序列 $(\mathbf{X}_t)_{t\in\mathbb{Z}}$ 的无瞬时效应 SCM，诱导联合分布忠实于对应全时间图. 则汇总图含 $X^j \to X^k$，当且仅当存在 $t \in \mathbb{Z}$ 使

$$X^k_t \not\perp\!\!\!\perp X^j_{\mathrm{past}(t)} \mid \mathbf{X}^{-j}_{\mathrm{past}(t)}. \tag{10.3}$$

为完整起见，附录 C.14 收录证明. 类似结果见 White 与 Lu [2010] 和 Eichler [2011, 2012]. 正如定理标题所示，这是第 10.3.3 节进一步讨论的 Granger 因果的基础.

10.3.2 有些因果结论不需要忠实性

值得注意的是，即使不使用忠实性，也可从条件依赖作出有意义的因果结论. 这与独立同分布情形不同：后者的任意分布，都相对于任意节点顺序的完全 DAG 满足 Markov 性. 由于时间不能倒流，只要已知汇总图为 $X \to Y$ 或 $Y \to X$ 中之一，时间序列的 Markov 条件就足以判断是哪一种.

定理 10.4（检测箭头 $X \to Y$） 考虑双变量时间序列 $(X_t, Y_t)_{t\in\mathbb{Z}}$ 的 SCM.

(i) 若存在 $t \in \mathbb{Z}$ 使

$$Y_t \not\perp\!\!\!\perp X_{\mathrm{past}(t)} \mid Y_{\mathrm{past}(t)}, \tag{10.4}$$

则汇总图含从 X 到 Y 的箭头.

(ii) 进一步假设无瞬时效应，任意有限变量子集的联合密度严格为正. 若对全部 $t \in \mathbb{Z}$，

$$Y_t \perp\!\!\!\perp X_{\mathrm{past}(t)} \mid Y_{\mathrm{past}(t)}, \tag{10.5}$$

则汇总图不含从 X 到 Y 的箭头.

同样，尽管此证明可能已见于其他文献，附录 C.15 为完整起见收录它. 证明 (ii) 需要严格弱于忠实性的因果极小性. 译注：源定理的假设列表未显式列出因果极小性，源文紧接着却说明证明需要它. *(ii)* 应在该额外假设下理解；若允许图中包含实际不起作用的父变量，单靠正密度和独立关系不能排除冗余箭头. 下一小节将看到，本定理及其变体 [例如 White 与 Lu, 2010；Eichler, 2011, 2012] 将基于条件独立的因果发现与 Granger 因果联系起来.

10.3.3 Granger 因果

为简单起见，先考虑双变量版本.

定理 10.4 表明，在排除瞬时效应并满足温和技术条件时，检验式 (10.5) 及交换 X, Y 的对应陈述，就可判断汇总图是否有箭头，从而区分 $X \quad Y$、$X \to Y$、$X \leftarrow Y$、$X \rightleftarrows Y$ 四种汇总图. 当 X 的过去帮助由 Y 自身过去预测 Y 时，就推断 X 影响 Y. 形式上写为

$$X \text{ Granger 导致} Y \quad :\Longleftrightarrow \quad Y_t \not\perp\!\!\!\perp X_{\mathrm{past}(t)} \mid Y_{\mathrm{past}(t)}. \tag{10.6}$$

这一思路已可追溯至 Wiener [1956，第 189–190 页]：若预测 Y 时，在其自身过去之外再纳入 X 能改善预测，则 X 对 Y 有因果影响. 图 10.6 是定理 10.4 成立的典型场景.

Granger 因果常指线性预测，此时比较两种线性回归模型：

$$Y_t = \sum_{i=1}^{q} a_i Y_{t-i} + N_t, \tag{10.7}$$

$$Y_t = \sum_{i=1}^{q} a_i Y_{t-i} + \sum_{i=1}^{q} b_i X_{t-i} + \widetilde{N}_t, \tag{10.8}$$

分别假设 $(N_t)_{t\in\mathbb{Z}}$、$(\widetilde{N}_t)_{t\in\mathbb{Z}}$ 为独立同分布时间序列. 当纳入 X 后噪声 $\widetilde{N}_t$ 的方差，显著小于不含 X 时 N_t 的方差，就推断 X Granger 导致 Y. 这相当于给定 $Y_{\text{past}(t)}$ 时，Y_t 与 $X_{\text{past}(t)}$ 有非零偏相关；对多元高斯分布，这等价于依赖陈述 (10.4). 非线性回归变体也已有广泛研究［例如 Ancona 等, 2004；Marinazzo 等, 2008］. 式 (10.5) 的非参数检验见例如 Diks 与 Panchenko [2006] 及其中参考文献.

给定 Y 的过去，度量 Y_t 与 X 过去之间依赖的信息论量是*转移熵*（transfer entropy）[Schreiber, 2000]：

$$\mathrm{TE}(X\to Y) := I(Y_t : X_{\text{past}(t)} \mid Y_{\text{past}(t)}), \tag{10.9}$$

其中 $I(A:B\mid C)$ 为任意三个变量集合的条件互信息［Cover 与 Thomas, 1991］，另见附录 A. 因此，估计转移熵并在它显著大于 0 时推断 X 导致 Y，可视为考虑任意非线性影响的 Granger 因果信息论实现. 很容易进一步把转移熵当作 X 对 Y 影响强度的度量，但下面的 “Granger 因果的局限” 会解释为何不恰当.

定理 10.4 中双变量时间序列的因果充分性假设常不适当，Granger [1980] 已讨论此点. 因而定义：若

$$X^k_t \not\perp\!\!\!\perp X^j_{\text{past}(t)} \mid \mathbf{X}^{-j}_{\text{past}(t)},$$

则称 X^j Granger 导致 X^k. Granger 早已强调，正确使用该概念实际上要求对世界中全部相关变量取条件. 尽管如此，人们仍常使用双变量版本，或将其用于明显有重要变量未观测的情形；若作因果解释，就可能产生误导.

与前面独立同分布设置一样，因果不充分是因果时间序列分析的严重问题. 只观测双变量时间序列 $(X_t,Y_t)_{t\in\mathbb{Z}}$，假设二者均受隐藏时间序列 $(Z_t)_{t\in\mathbb{Z}}$ 先前实例影响，如图 10.7(a)：Z 以滞后 1 影响 X，以滞后 2 影响 Y. 假设忠实性，d 分离判据给出

$$\begin{aligned} Y_t &\not\perp\!\!\!\perp X_{\text{past}(t)} \mid Y_{\text{past}(t)},\\ X_t &\perp\!\!\!\perp Y_{\text{past}(t)} \mid X_{\text{past}(t)}. \end{aligned}$$

所以直接套用 Granger 因果，会推断 X 导致 Y 而 Y 不导致 X. 黄油与奶酪价格的关系例如有此现象：二者都受牛奶价格强烈影响，但奶酪生产耗时比黄油长得多，导致牛奶与奶酪价格间滞后更大［Peters 等, 2013，实验 10］. 这种失败只因并未观测全部相关变量，而这正是 Granger 本人列明的要求.

Ay 与 Polani [2008] 给出图 10.7(b) 的第二个失败场景. 假设 X_{t-1} 以确定的复制操作影响 Y_t，即 $Y_t := X_{t-1}$；同样，Y_{t-1} 的值复制给 X_t. 显然 X,Y 直观上强烈相互影响：干预 X_t 会改变所有 Y_{t+1+2k}，$k\in\mathbb{N}_0$；干预 Y_t 同样改变所有 X_{t+1+2k}. 但 X 的过去无助于由 Y 过去预测 Y_t，因为仅由 Y 自身过去就已可完美预测. 确定关系一般会诱导额外独立性，从而使基于条件独立的因果推断困难. 例如因果链 $X\to Y\to Z$ 中若 Y 为 X 的函数，则 $Y \perp\!\!\!\perp Z \mid X$，而这不是此结构的典型性质. 因而可以认为该例人为，更自然的版本是带噪复制. 对二元 X_t,Y_t，Janzing 等 [2013，例 7] 表明，复制操作噪声趋于

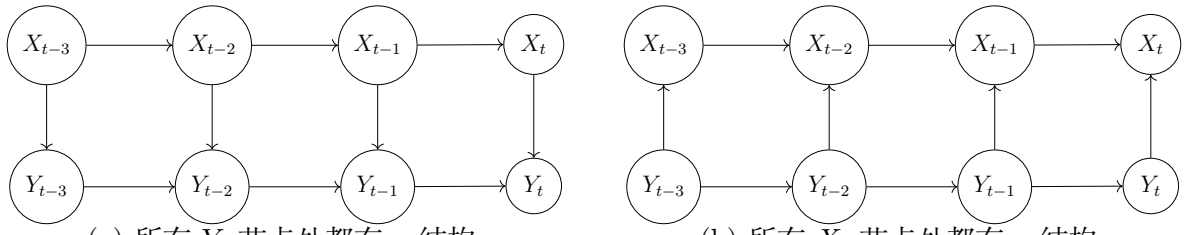
0 时，转移熵也趋于 0. 此时 Granger 因果确实推断双向因果，但小噪声下 X 过去带来的微小预测改善，不能恰当反映仍然直观强烈的相互影响.

因此，转移熵不是度量一个时间序列对另一个因果影响强度的恰当指标. Janzing 等 [2013] 讨论了时间序列及独立同分布设置下各种因果影响量化方案的局限，并提出另一种信息论因果强度度量. 总结本段，在因果充分的两个时间序列中，因果影响存在与否的定性判断，只在相当人为的场景下失败；但用转移熵量化因果影响，即用信息论解释 “预测改善”，在不那么人为的情形也可能有问题.

还有一种场景中，Granger 因果的定量结果具有误导性，但除非违反忠实性，定性陈述仍正确（不过涉及瞬时效应；有人可能认为足够精细的时间分辨率会使其消失 [Granger, 1988]）. 对图 10.8(a)，d 分离给出

$$Y_t \perp\!\!\!\perp X_{\mathrm{past}(t)} \mid Y_{\mathrm{past}(t)}.$$

只有当前 X_t 有助于预测 Y_t，过去 $X_{t-1}, X_{t-2}, \ldots$ 无用，因此 Granger 因果不提出 $X \to Y$ 的连接. 但在图 (b) 中，即使影响仍是纯瞬时的，假设忠实性时 Granger 因果仍可检测到 X 对 Y 的影响；然而微小预测改善无法恰当反映 X_t 对 Y_t 可能很强的影响. 为处理瞬时效应，人们提出在相应 SCM 加入瞬时项的变体，但此时可识别性可能失效 [例如 Lütkepohl, 2007，式 (2.3.20)、(2.3.21)]. 已知系统含瞬时效应时，可能想把式 (10.8) 中 Y_t 的回归变量从 $X_{\mathrm{past}(t)}$ 改为 $X_t \cup X_{\mathrm{past}(t)}$. 但如 Granger [1988] 已指出的，这可能得出错误结论：X_t 帮助预测 Y_t，既可能表示 X_t 影响 Y_t，也可能表示 Y_t 影响 X_t.



(a) 所有 Y_t 节点处都有 v 结构.　　(b) 所有 X_t 节点处都有 v 结构.

图 10.5: 两个 DAG 虽仅在瞬时效应方向上不同，却并不 Markov 等价.

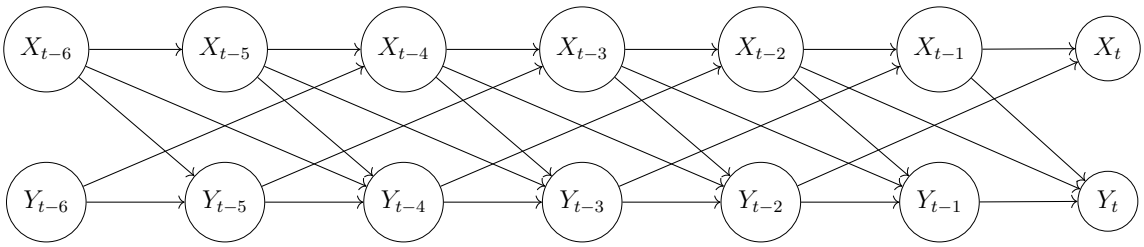
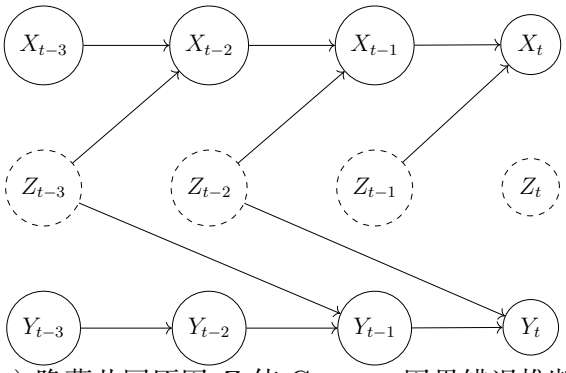
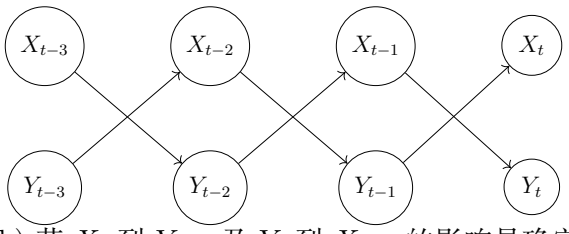


图 10.6: Granger 因果有效的典型场景：若删去全部 X 到 Y 的箭头，给定自身过去时，Y_t 将与 X 过去条件独立. 本图中仍依赖，所以式 (10.4) 证明 X 对 Y 有影响.

注 10.5（模型设定错误可能有帮助）　上述认识带来一个看似矛盾的信息：即使变量会瞬时影响其他变量，在推断因果陈述时，检查一个变量的过去是否帮助预测，比检查其过去和当前值是否帮助预测更有结论性. 定理 10.4(i) 并不排除瞬时效应. 所以在因果充分前提下，$X_{\mathrm{past}(t)}$ 对由 $Y_{\mathrm{past}(t)}$ 预测 Y_t 的任何帮助，仍可归因于 X 对 Y 的影响. 而

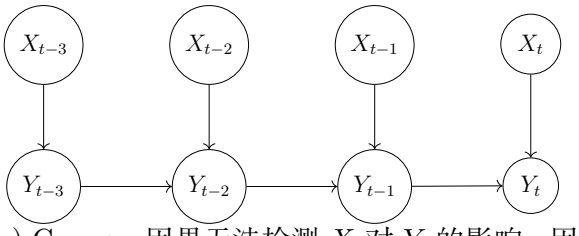


(a) 隐藏共同原因 Z 使 Granger 因果错误推断 X 影响 Y.

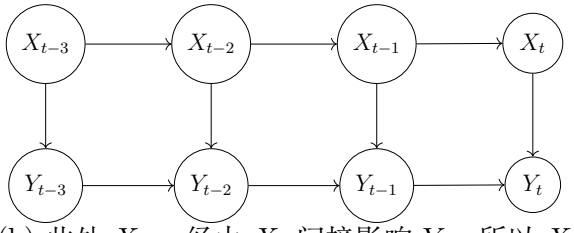


(b) 若 X_t 到 Y_{t+1} 及 Y_t 到 X_{t+1} 的影响是确定的，则 Granger 因果错误推断两个方向都无因果影响.

图 10.7: 这些例子中，Granger 因果推断的图结构不正确.



(a) Granger 因果无法检测 X 对 Y 的影响，因为 X 过去只经由 Y 过去影响 Y_t.



(b) 此处 X_{t-1} 经由 X_t 间接影响 Y_t，所以 X 过去仍帮助预测 Y_t，Granger 因果仍可检测 X 对 Y 的影响.

图 10.8: 两个含瞬时效应的场景：Granger 因果在 (a) 未能检测它，在 (b) 则能检测.

且只要 X 对 Y 有影响，无论是否纯瞬时，一般情形下，给定 $Y_{\mathrm{past}(t)}$ 时 $X_{\mathrm{past}(t)}$ 会改善对 Y_t 的预测. 译注：这里的 “一般情形” 是源文的 *generic* 限定，并非无条件保证；前面的图 *(a)* 本身就给出过去不能改善预测的结构.

10.3.4 受限函数类模型

为处理 Granger 因果的局限，Hyvärinen 等 [2008] 提出线性非高斯自回归模型，使含瞬时效应的因果结构可识别. Peters 等 [2013] 讨论如何使用式 (10.1) 中限制更弱的函数类 f^j 完成这一任务. 例如将 ANM 用于时间序列，采用 SCM

$$X_t^j := f^j\big((\mathbf{PA}_q^j)_{t-q}, \ldots, (\mathbf{PA}_1^j)_{t-1}, (\mathbf{PA}_0^j)_t\big) + N_t^j,$$

$j \in \{1, \ldots, d\}$. 除了识别 Markov 等价类内因果结构，受限函数类还有第二个动机：Peters 等 [2013] 通过模拟时间序列，为 “允许受限函数类模型的时间序列较不易受混杂” 这一看法提供了一些经验依据.

10.3.5 谱独立判据

谱独立判据（spectral independence criterion，SIC）基于原因与机制独立的思想，由 Shajarisales 等 [2015] 描述. 设有弱平稳双变量时间序列 $(X_t, Y_t)_{t\in\mathbb{Z}}$，其中 X 经线性时不变滤波器影响 Y，或反之. 更明确地，在 X 影响 Y 时，Y 是 X 与函数 h 的卷积：

$$Y_t = \sum_{k=1}^{\infty} h(k) X_{t-k}. \tag{10.10}$$

使该式及以下表达有定义的 h 衰减条件等技术细节，见 Shajarisales 等 [2015]. 为形式化 X, h 的独立条件，考虑滤波器在频域的作用. 对 $\nu \in [-1/2, 1/2]$，$S_{XX}(\nu)$ 为频率 ν 的功率谱密度，它是自协方差函数

$$C_{XX}(\tau) := E[X_t X_{t+\tau}], \qquad \tau \in \mathbb{Z}$$

的 Fourier 变换. 译注：源式未减均值项；若将其称为自协方差，需要零均值约定，否则此式是自相关二阶矩. 此处保留原式. 由式 (10.10) 得

$$S_{YY}(\nu) = |\widetilde{h}(\nu)|^2 S_{XX}(\nu), \tag{10.11}$$

其中 $\widetilde{h}(\nu) = \sum_{k\in\mathbb{Z}} e^{-i2\pi k\nu} h(k)$ 为 h 的 Fourier 变换. 即输入时间序列功率谱乘以滤波器传递函数模平方，得到输出功率谱. $\widetilde{h}$ 可逆时还有

$$S_{XX}(\nu) = \left|\frac{1}{\widetilde{h}(\nu)}\right|^2 S_{YY}(\nu). \tag{10.12}$$

两式都成立，问题是哪一式描述因果模型. 思路是，在因果方向，输入时间序列的功率谱不包含滤波器传递函数的信息. Shajarisales 等 [2015] 用以下独立条件形式化它.

定义 10.6（SIC） 若 S_{XX} 与 $\widetilde{h}$ 不相关，即

$$\langle S_{XX}|\widetilde{h}|^2\rangle = \langle S_{XX}\rangle\langle|\widetilde{h}|^2\rangle, \tag{10.13}$$

则称时间序列 X 与滤波器 h 满足 SIC. 其中 $\langle f\rangle$ 表示频率区间上的平均，定义为

$$\langle f\rangle := \int_{-1/2}^{1/2} f(\nu)\,d\nu.$$

译注：源文写作 S_{XX} 与 $\widetilde{h}$ 不相关，但显示式实际要求 S_{XX} 与 $|\widetilde{h}|^2$ 不相关；以显示式为本定义的精确条件，保留原措辞区别.

Shajarisales 等 [2015] 表明，除 $|\widetilde{h}|$ 在整个频率区间为常数这一非一般情形外，式 (10.13) 蕴含反向对应的独立条件不成立. **定理 10.7（经由 SIC 的可识别性）** 若式 (10.13) 成立，且 $|\widehat{h}|$ 不随 ν 恒定，则 S_{YY} 与 $1/|\widetilde{h}|$ 负相关，即

$$\langle S_{YY}/|\widetilde{h}|^2\rangle < \langle S_{YY}\rangle\langle 1/|\widetilde{h}|^2\rangle. \tag{10.14}$$

译注：源陈述中帽号 $\widehat{h}$ 与此前 $\widetilde{h}$ 不同，且文字写 $1/|\widetilde{h}|$、显示式用其平方，此处均保留. 严格 *Jensen* 不等式还须相应积分有限、$|\widetilde{h}|>0$ 几乎处处，且其模在几乎处处意义下非恒定；非零输入功率也不可省略. 零输入谱时两侧均为 0，不产生严格不等式.

证明： 式 (10.13) 和 (10.14) 左侧分别为 $\langle S_{YY}\rangle$、$\langle S_{XX}\rangle$. Jensen 不等式给出 $1/\langle|\widetilde{h}|^2\rangle < \langle 1/|\widetilde{h}|^2\rangle$，从而得到结论. □

Shajarisales 等 [2015] 提出简单算法，检查哪个方向更接近满足 SIC，并报告它在多种模拟和真实数据实验中得到一些鼓舞性结果.

10.4 动态因果建模

动态因果建模（dynamic causal modeling，DCM）特别为推断不同脑区活动间的因果关系而开发［Friston 等, 2003］. 若向量 $\mathbf{z}\in\mathbb{R}^n$ 编码 n 个脑区活动，$\mathbf{u}\in\mathbb{R}^m$ 为扰动向量，则动力学由下式给出：

$$\frac{d}{dt}\mathbf{z} = F(\mathbf{z},\mathbf{u},\boldsymbol{\theta}), \tag{10.15}$$

其中 F 为已知函数，$\mathbf{u}$ 为外部刺激，$\boldsymbol{\theta}$ 参数化描述不同脑区因果连接的模型类. 常考虑双线性近似

$$\frac{d}{dt}\mathbf{z} = \left(A + \sum_{j=1}^{m} u_j B^j\right)\mathbf{z} + C\mathbf{u}, \tag{10.16}$$

其中 $A, B^1,\dots,B^m$ 为 $n\times n$ 矩阵，C 为 $n\times m$ 矩阵. A 描述不同区域活动 z_j 的相互影响，B^j 描述 $\mathbf{u}$ 如何改变这种相互影响，C 编码 $\mathbf{u}$ 对 $\mathbf{z}$ 的直接影响.

$\mathbf{z}$ 不可直接观测，但可检测血流动力学响应：血流增加氧和葡萄糖等营养物质的供应，以补偿增加的能量需求. 功能磁共振成像（fMRI）能通过血氧水平依赖（BOLD）

信号检测这种增加. 定义包含脑活动和血流动力学状态变量的状态向量 $\mathbf{x}$，将式 (10.16) 与血流动力学响应模型结合，得到

$$\frac{d}{dt}\mathbf{x} = f(\mathbf{x}, \mathbf{u}, \boldsymbol{\theta}). \tag{10.17}$$

高维参数 $\boldsymbol{\theta}$ 包含式 (10.16) 的全部自由参数及血流动力学模型参数. 再建模 $\mathbf{x}$ 如何确定测得的 BOLD 信号 $\mathbf{y}$：

$$\mathbf{y} = \lambda(\mathbf{x}). \tag{10.18}$$

最终获得的观测数据是 $\mathbf{y}$ 向量的时间序列. DCM 用期望最大化（EM）等学习潜变量模型的已知技术，由数据推断式 (10.16) 中的矩阵.

Lohmann 等 [2012a] 对 DCM 的主要批评是：参数数量随 n, m 增加而爆炸，无法从经验数据识别. 在他们模拟脑连接的实验中，大量错误模型得到的 DCM 证据高于真实模型. 这些发现引发讨论；另见 Friston 等 [2013] 的回应，以及 Lohmann 等 [2012b] 对该回应的答复.

10.5 习题

问题 10.8（无环汇总图） 证明定理 10.2.

问题 10.9（瞬时效应） 考虑多元时间序列上的 SCM，每个 X_t^j 均受所有分量 X^k 全部过去值影响. 再假设瞬时效应构成 DAG，分布相对于全时间图满足 Markov 性与忠实性. 能在多大程度上从分布识别瞬时 DAG 结构?

问题 10.10（Granger 因果） 说明若在图 10.7(a) 中对全部 $t \in \mathbb{Z}$ 加边 $Z_t \to Z_{t+1}$，为何 Granger 因果会得出 “X Granger 导致 Y” 和 “Y Granger 导致 X”.

Appendix A

概率与统计补充

A.1 基本定义

(i) 底层概率空间记为 $(\Omega, \mathcal{F}, P)$，其中 $\Omega, \mathcal{F}, P$ 分别为集合、σ 代数和概率测度.

(ii) 实值随机变量用大写字母表示，例如 $X : (\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ 是相对于 Borel σ 代数的可测函数. 随机向量是可测函数 $\mathbf{X} : (\Omega, \mathcal{F}) \to (\mathbb{R}^d, \mathcal{B}_{\mathbb{R}^d})$. 若不存在 $\mathbf{c} \in \mathbb{R}^d$ 使 $P(\mathbf{X} = \mathbf{c}) = 1$，则称 $\mathbf{X}$ 非退化. 测度论入门例如见 Dudley [2002].

(iii) 通常用粗体表示向量. 稍微滥用记号，把变量集合 $\mathbf{B} \subseteq \mathbf{X}$ 当作单个多元变量.

(iv) $P_{\mathbf{X}}$ 为 d 维随机向量 $\mathbf{X}$ 的分布，即 $(\mathbb{R}^d, \mathcal{B}_{\mathbb{R}^d})$ 上的概率测度.

(v) 密度记为 $\mathbf{x} \mapsto p_{\mathbf{X}}(\mathbf{x})$，或简写 $\mathbf{x} \mapsto p(\mathbf{x})$，即 $P_{\mathbf{X}}$ 相对于乘积测度的 Radon–Nikodym 导数. 有时隐含假定其存在或连续.

(vi) 当且仅当对所有 x, y，

$$p(x, y) = p(x)p(y), \tag{A.1}$$

称 X, Y 独立，记为 $X \perp\!\!\!\perp Y$. 否则称二者依赖，记为 $X \not\perp\!\!\!\perp Y$.

(vii) 当且仅当对所有 $x_1, \ldots, x_d$，

$$p(x_1, \ldots, x_d) = p(x_1) \cdots p(x_d), \tag{A.2}$$

称 $X_1, \ldots, X_d$ 联合（相互）独立. 联合独立蕴含任意 $i \neq j$ 时 X_i, X_j 独立；逆命题一般不成立，两两独立不蕴含联合独立.

(viii) 当且仅当对所有满足 $p(z) > 0$ 的 x, y, z，

$$p(x, y \mid z) = p(x \mid z)p(y \mid z), \tag{A.3}$$

称给定 Z 时 X, Y 条件独立，记为 $X \perp\!\!\!\perp Y \mid Z$. 否则称给定 Z 时依赖，记为 $X \not\perp\!\!\!\perp Y \mid Z$. 译注：这些密度等式沿源文写为 “所有” 点；一般密度仅几乎处处有意义，逐点表述须选适当版本或附连续性等条件.

(ix) 条件独立服从以下重要规则［例如 Pearl, 2009，第 1.1.5 节］：

$$
\begin{aligned}
X \perp\!\!\!\perp Y \mid Z &\;\Rightarrow\; Y \perp\!\!\!\perp X \mid Z && \text{（对称性），}\\
X \perp\!\!\!\perp (Y,W) \mid Z &\;\Rightarrow\; X \perp\!\!\!\perp Y \mid Z && \text{（分解性），}\\
X \perp\!\!\!\perp (Y,W) \mid Z &\;\Rightarrow\; X \perp\!\!\!\perp Y \mid (W,Z) && \text{（弱并性），}\\
\left.\begin{array}{l} X \perp\!\!\!\perp Y \mid Z \\ X \perp\!\!\!\perp W \mid (Y,Z) \end{array}\right\} &\;\Rightarrow\; X \perp\!\!\!\perp (Y,W) \mid Z && \text{（收缩性），}\\
\left.\begin{array}{l} X \perp\!\!\!\perp Y \mid (W,Z) \\ X \perp\!\!\!\perp W \mid (Y,Z) \end{array}\right\} &\;\Rightarrow\; X \perp\!\!\!\perp (Y,W) \mid Z && \text{（交性质）．}
\end{aligned}
$$

严格正密度的存在足以保证交性质．离散情形的必要充分条件见 Drton 等 [2009b，习题 6.6] 和 Fink [2011]；连续情形见 Peters [2014].

(x) 若 $E[X^2] < \infty$，随机变量 X 的方差定义为

$$\operatorname{var}[X] := E[(X - E[X])^2] = E[X^2] - E[X]^2.$$

(xi) 若 $E[X^2], E[Y^2] < \infty$ 且 $E[XY] = E[X]E[Y]$，即

$$\rho_{X,Y} := \frac{E[XY] - E[X]E[Y]}{\sqrt{\operatorname{var}[X]\operatorname{var}[Y]}} = 0,$$

则称 X, Y 不相关．否则即 $\rho_{X,Y} \neq 0$ 时称相关；$\rho_{X,Y}$ 称为相关系数．译注：相关系数商式要求两方差非零；零方差时仍可用协方差为零定义不相关，但该商无定义．

(xii) 独立蕴含不相关：$X \perp\!\!\!\perp Y \Rightarrow \rho_{X,Y} = 0$．逆方向未必成立，见代码片段 A.1．只在二元高斯或二元变量等特殊情形中，逆命题也成立．译注：这里沿用上一项有限二阶矩及商式有定义的条件；“二元变量”指各取两个值的变量，而非任意二维随机向量．

(xiii) 若

$$\rho_{X,Y|Z} := \frac{\rho_{X,Y} - \rho_{X,Z}\rho_{Z,Y}}{\sqrt{(1-\rho_{X,Z}^2)(1-\rho_{Z,Y}^2)}} = 0,$$

则称给定 Z 时 X, Y 偏不相关．偏相关的重要解释是：它等于分别将 X 对 Z、Y 对 Z 作线性回归后残差的相关系数．译注：此处单变量公式需各相关系数有定义且分母非零；完全线性预测时残差相关未必有定义．

(xiv) 一般而言，见例 7.9，

$$
\begin{aligned}
\rho_{X,Y|Z} = 0 &\;\not\Rightarrow\; X \perp\!\!\!\perp Y \mid Z,\\
\rho_{X,Y|Z} = 0 &\;\not\Leftarrow\; X \perp\!\!\!\perp Y \mid Z.
\end{aligned}
$$

(xv) 回归估计中，通常给定联合分布 $P_{X,Y}$ 的独立同分布样本 $(X_1,Y_1),\dots,(X_n,Y_n)$，目标是由协变量（预测变量）$X$ 预测目标 Y. 例如最小二乘回归寻找

$$\widehat{f}=\operatorname*{argmin}_{f\in\mathcal{F}}\sum_{i=1}^{n}(Y_i-f(X_i))^2.$$

这里在函数类 $\mathcal{F}$ 上优化，见第 A.3 节. 不同回归技术使用不同函数类. 线性回归只考虑线性 f，例见代码片段 6.43；代码片段 4.14 展示非线性回归的例子.

(xvi) 离散随机变量集合 $\mathbf{X},\mathbf{Y}$ 间的依赖可用 Shannon 互信息度量 [Cover 与 Thomas, 1991]：

$$I(\mathbf{X}:\mathbf{Y}):=\sum_{\mathbf{x},\mathbf{y}}p(\mathbf{x},\mathbf{y})\log\frac{p(\mathbf{x},\mathbf{y})}{p(\mathbf{x})p(\mathbf{y})}.$$

(xvii) 给定集合 $\mathbf{Z}$ 时，离散随机变量集合 $\mathbf{X},\mathbf{Y}$ 的条件依赖由条件 Shannon 互信息度量 [Cover 与 Thomas, 1991]：

$$I(\mathbf{X}:\mathbf{Y}\mid\mathbf{Z}):=\sum_{\mathbf{x},\mathbf{y},\mathbf{z}}p(\mathbf{x},\mathbf{y},\mathbf{z})\log\frac{p(\mathbf{x},\mathbf{y}\mid\mathbf{z})}{p(\mathbf{x}\mid\mathbf{z})p(\mathbf{y}\mid\mathbf{z})}.$$

(xviii) 连续变量时，将求和替换为积分：

$$I(\mathbf{X}:\mathbf{Y}):=\int p(\mathbf{x},\mathbf{y})\log\frac{p(\mathbf{x},\mathbf{y})}{p(\mathbf{x})p(\mathbf{y})}\,d\mathbf{x}\,d\mathbf{y},$$
$$I(\mathbf{X}:\mathbf{Y}\mid\mathbf{Z}):=\int p(\mathbf{x},\mathbf{y},\mathbf{z})\log\frac{p(\mathbf{x},\mathbf{y}\mid\mathbf{z})}{p(\mathbf{x}\mid\mathbf{z})p(\mathbf{y}\mid\mathbf{z})}\,d\mathbf{x}\,d\mathbf{y}\,d\mathbf{z}.$$

A.2 独立与条件独立检验

实践中给定有限样本 $(X_1,Y_1),\dots,(X_n,Y_n)\overset{\text{iid}}{\sim}P_{X,Y}$，希望判断底层随机变量是否独立. 经验相关系数（或其他独立性度量）不会恰好为 0，因此必须考虑依赖度量的随机波动，可用统计假设检验实现. 考虑原假设 $H_0:X\perp\!\!\!\perp Y$ 和备择 $H_A:X\not\perp\!\!\!\perp Y$，构造把有限样本映射为实数的统计量 T_n，并按如下规则判断：

$$(x_1,y_1),\dots,(x_n,y_n)\longmapsto\begin{cases}H_0, & T_n\le c,\\ H_A, & T_n>c.\end{cases}$$

T_n 简记 $T_n((x_1,y_1),\dots,(x_n,y_n))$. 阈值 $c\in\mathbb{R}$ 选择为可控制第一类错误：对任意满足 H_0 的 P，有 $P(T_n>c)\le\alpha$，α 为用户指定的显著性水平. 由数据计算 T_n；若 $T_n>c$ 就拒绝原假设，我们可相对有信心认为判断正确；否则不拒绝，但这未必说明很多，因为样本量可能太小而检不出依赖. 检验的 p 值为使原假设被拒绝的最小显著性水平. 译注：第一类错误控制是关于重复抽样下拒绝概率的保证，不能解释为给定数据后原假设为真的概率，或某次判断正确的后验概率.

下面简述几种 T_n 选择；检验还有很多，不声称所列过程最优，实践例子见代码片段 A.1.

(i) 检验相关系数为零，可用经验相关系数及 t 检验（对高斯变量），或 Fisher 的 z 变换，例如 R Core Team [2016] 的 `cor.test`.

(ii) 对离散或离散化数据，可用 χ^2 独立性检验，例如 `chisq.test`（R Core Team, 2016）.

(iii) 一般非参数独立性检验的例子为 Hilbert–Schmidt 独立性判据（HSIC）[Gretton 等, 2008]. 思路是将分布单射地映到再生核 Hilbert 空间（RKHS）[Schölkopf 与 Smola, 2002]. 给定正定核，将概率分布映至相应 RKHS $\mathcal{H}$，即 $P_{X,Y} \mapsto \mu(P_{X,Y}) \in \mathcal{H}$. 对所谓特征核，如高斯核，该映射为单射. 特别有

$$\mu(P_{X,Y}) = \mu(P_X \otimes P_Y) \quad \Longleftrightarrow \quad P_{X,Y} = P_X \otimes P_Y,$$

后者当且仅当 X, Y 独立. HSIC 定义为联合分布与边缘乘积分布的 RKHS 距离平方：

$$\mathrm{HSIC}(P_{X,Y}) := \|\mu(P_{X,Y}) - \mu(P_X \otimes P_Y)\|^2_{\mathcal{H}}.$$

可用其估计量作为 T_n. 独立时 HSIC 为 0，预期 T_n 较小；阈值选择见 Gretton 等 [2008].

也可将 HSIC 表为协方差算子 C_{XY} 的 Hilbert–Schmidt 范数. 该算子定义为：对相应 RKHS 中任意 f, g，

$$\langle f, C_{XY} g \rangle = E[f(X)g(Y)] - E[f(X)]E[g(Y)].$$

译注：源文此处写 “范数”，而前面 *HSIC* 定义为距离平方；常用对应关系是 *HSIC* 等于交叉协方差算子的 *Hilbert–Schmidt* 范数平方. 此处保留两处原表述，明确区别. 交叉协方差算子扩展协方差矩阵：若 X, Y 的维数为 d_X, d_Y，相应 RKHS 分别同构于 $\mathbb{R}^{d_X}, \mathbb{R}^{d_Y}$，则 C_{XY} 可由 $d_X \times d_Y$ 交叉协方差矩阵描述. 协方差矩阵为零显然未必独立；但对于特征核，相应 RKHS 为无限维、不同构于 $\mathbb{R}^d$，交叉协方差算子范数为零当且仅当 X, Y 独立. 译注：此处无限维叙述针对通常连续域上的高斯等核；有限取值域上特征核也可具有有限维 *RKHS*，不应把无限维视为特征核的一般定义.

Pfister 等 [2017] 将过程推广到检验 d 个变量联合独立，例如可检验噪声变量的联合独立. 他们提供双变量及多变量过程的代码，见 R 包 `dHSIC`. 实践中通常须选核参数；对高斯核，许多实现用所谓中位数启发式选择带宽 σ [例如 Gretton 等, 2008].

(iv) 条件独立检验. 这是困难问题，特别当条件集很大时. 精确形式化其困难程度仍在研究，以下例子说明难点. 若 $Z_1, \ldots, Z_d$ 为二元变量，则

$$\begin{aligned} & X \perp\!\!\!\perp Y \mid Z_1, \ldots, Z_d \\ & \quad \Longleftrightarrow \quad \forall (z_1, \ldots, z_d) \in \{0,1\}^d : \; X \perp\!\!\!\perp Y \mid Z_1 = z_1, \ldots, Z_d = z_d. \end{aligned}$$

若无法对 X, Y 如何依赖各 Z 作假设，就需对全部 2^d 种赋值分别作无条件独立检验；例如 Z_d 可为 X, Y 的共同子节点，而依赖只在其他 $Z_1, \ldots, Z_{d-1}$ 的某个特定赋值下可检测. 译注：条件概率与条件检验只在相应赋值概率非零时有定义；零概率格不须也不能按通常方式检验. 对连续变量，已有 HSIC 扩展. Fukumizu 等 [2008] 将思路推广到条件交叉协方差算子，以得到条件独立检验. Zhang 等 [2011] 进一步发展，并给出原假设下统计量分布的近似.

代码片段 A.1 以下代码生成两个不相关但依赖的变量的样本. 保留源代码及其注释和所示输出；未在此运行统计实验.

```
library(dHSIC)
#
# generates a sample from two uncorrelated but dependent random variables
set.seed(1)
A <- runif(200)-0.5
B <- runif(200)-0.5
X <- t( c(cos(pi/4), -sin(pi/4)) %*% rbind(A, B) )
Y <- t( c(sin(pi/4), cos(pi/4)) %*% rbind(A, B) )
#
# performs the statistical test
cor.test(X,Y)$p.value
# 0.3979561
dhsic.test(X,Y)$p.value
# 1.970705e-08
```

A.3 函数类的容量

这里讨论：最小化经验风险 (1.3) 的函数序列，是否收敛到也最小化风险 (1.2) 的函数，见第 1.2 节. 由大数定律，对任意固定 $f \in \mathcal{F}$ 和 $\varepsilon > 0$，

$$\lim_{n\to\infty} P\big(|R[f] - R^n_{\text{emp}}[f]| > \varepsilon\big) = 0, \tag{A.4}$$

且由 Chernov 界控制指数快收敛［例如 Vapnik, 1998］. 但这不蕴含经验风险最小化的一致性，因为 f 是通过最小化 (1.3) 选择的. 虽然 (x_i, y_i) 独立，误差（损失）$\frac{1}{2}|f(x_i) - y_i|$ 却不独立，通常形式的大数定律不适用. 为得到一致性，需要一致大数定律［Vapnik, 1998］：对所有 $\varepsilon > 0$，

$$\lim_{n\to\infty} P\left(\sup_{f\in\mathcal{F}}(R[f] - R^n_{\text{emp}}[f]) > \varepsilon\right) = 0. \tag{A.5}$$

此性质取决于函数类 $\mathcal{F}$.

若选择 $\mathcal{F} = \mathcal{Y}^{\mathcal{X}}$，即 $\mathcal{X}$ 到 $\mathcal{Y}$ 的全部函数，如何？不幸的是，这不导出式 (A.5). 原因如下：设依据现有样本 (1.1) 选出好解 f^*，例如在全部样本点满足 $f^*(x_i) = y_i$. 构造另一个函数 f^{**}，在样本点与 f^* 一致，其他地方处处不同. 若 $P_{X,Y}$ 有密度，将来再次

恰好遇到任何训练点的概率为零，所以二函数几乎总不同. 但只靠训练集无法选择其一. 同样在式 (A.5) 中，找到差 $R[f^*] - R^n_{\mathrm{emp}}[f^*]$ 恰好较小的函数后，总能再构造一个差很大的 f^{**}，所以在所考虑的全部函数类情形，一致收敛不可能.

反之，$\mathcal{F}$ 越小，条件越弱. 如何度量其大小或容量超出本书范围，但若要给出不依赖底层分布的大小概括，只需一个数，即 $\mathcal{F}$ 的 VC（Vapnik–Chervonenkis）维. 它有时等于自由参数数，但也可能相差极大. 若 VC 维有限，对任意 $P_{X,Y}$，经验风险最小化均一致［Vapnik, 1998］. VC 维与可证伪性及 Popper 的理论维数概念相关［Corfield 等, 2009］. 统计学习理论的典型风险界为：对所有 $\delta > 0$，以概率 $1 - \delta$，对全部 $f \in \mathcal{F}$，

$$R[f] \le R^n_{\mathrm{emp}}[f] + \sqrt{\frac{h(\log(2n/h) + 1) - \log(\delta/4)}{n}}, \tag{A.6}$$

其中 h 为 $\mathcal{F}$ 的 VC 维. 若能找到 VC 维小、又含有足够适合任务的函数以获得小经验风险的 $\mathcal{F}$，就能以高概率保证这些函数在未来同分布数据上有小期望误差. 这描述了非平凡权衡：希望函数类大以减小经验风险，又希望它小以控制 h. 译注：本节沿用源书的分类学习背景. 指数偏差界、有限 VC 维的一致性与所示风险界还依赖适用损失（通常有界分类损失）、可测性等条件；不能不加条件推广到任意无界回归损失. 有意义的置信度取 $0 < \delta < 1$，风险界的 h, n 范围也须符合所引界的条件.

Appendix B

因果顺序与邻接矩阵

定义 B.1 给定 DAG $\mathcal{G}$，若置换，即双射

$$\pi : \{1, \dots, p\} \longrightarrow \{1, \dots, p\},$$

满足 $j \in \mathbf{DE}_i^{\mathcal{G}}$ 时 $\pi(i) < \pi(j)$，则称它为因果顺序，有时也称拓扑顺序.

由于 DAG 无环，总有拓扑顺序，见命题 B.2，但未必唯一. 节点 $\pi^{-1}(1)$ 没有父节点，因而为源节点；$\pi^{-1}(p)$ 没有后代，因而为汇节点.

命题 B.2 每个 DAG 都有拓扑顺序.

证明： 使用归纳法，只须证明每个 DAG 都有一个无祖先节点. 从任意节点出发，移至其某个父节点（若有）. 不会再遇到访问过的节点，否则就有有向环. 至多 $p-1$ 步后，到达无父节点的节点. □

定义 B.3 d 个节点上的有向图 $\mathcal{G} = (V, E)$ 可用取值为 0、1 的二元 $d \times d$ 矩阵 A 表示：

$$A_{i,j} = 1 \quad \Longleftrightarrow \quad (i, j) \in E.$$

A 称为 $\mathcal{G}$ 的邻接矩阵.

这种 DAG 表示尤其适用于高效实现算法. 邻接矩阵变换有若干有用结果，部分列举如下. **注 B.4**

(i) 设 A 为 DAG $\mathcal{G}$ 的邻接矩阵，平方矩阵 A^2 的 (i, j) 元等于从 i 到 j 长度为 2 的路径数，因为 $(A^2)_{i,j} = \sum_k A_{ik} A_{kj}$.

(ii) 一般有 $(A^k)_{ij} = \#\{\text{从} i \text{ 到} j \text{ 长度为} k \text{ 的路径}\}$.

(iii) 若下标沿有向路径增加，即 $j \in \mathbf{DE}_i^{\mathcal{G}}$ 蕴含 $j > i$，则恒等置换为因果顺序，邻接矩阵上三角，即仅右上半部分可有非零元.

(iv) 图稀疏时，可用稀疏矩阵节省空间和 / 或计算时间.

Robinson [1970, 1973] 与独立工作的 Stanley [1973] 研究了 d 节点 DAG 的数量. 此类矩阵（或 DAG）的数量随 d 增长极快，见表 B.1.

McKay [2004] 证明了 Eric W. Weisstein 猜想的以下等价描述. **定理 B.5** 矩阵 A 为某个 DAG $\mathcal{G}$ 的邻接矩阵，当且仅当 $A + I_d$ 是全部特征值均为严格正实数的 0–1 矩阵.

d	d 个节点的 DAG 数
1	1
2	3
3	25
4	543
5	29281
6	3781503
7	1138779265
8	783702329343
9	1213442454842881
10	4175098976430598143
11	3160345939641891760742 5
12	5219396513438294050205040 63
13	1867660074443203518666481692 6721
14	1439428141044398334941790719839535103
15	2377252655534103549921802182863767192535 05
16	8375667077373332028769930304799641223522313 8303
17	6270792119692388989944645260249492190696355148267 5201
18	9942119532215951589522891459235452451655502687858830501 4783
19	3327719012271075917361775733112611258835830762584219025835467735 05

表 B.1: DAG 数量随节点数 d 的变化，取自 http://oeis.org/A003024 [OEIS Foundation Inc., 2017]．数字长度增长快于任何线性项.

Appendix C

证明

C.1 定理 4.2 的证明

先给出一个引理；证明例如见 Peters [2008]. **引理 C.1** 设 X, N 独立，且 N 非确定. 则 $N \not\perp\!\!\!\perp (X + N)$.

定理 4.2 的证明： 若 X, N_Y 正态分布，则取

$$\beta := \frac{\operatorname{cov}[X,Y]}{\operatorname{cov}[Y,Y]} = \frac{\alpha \operatorname{var}[X]}{\alpha^2 \operatorname{var}[X] + \operatorname{var}[N_Y]},$$

并定义 $N_X := X - \beta Y$. 由构造 N_X, Y 不相关；因二者联合高斯，故也独立.

为证明 “仅当” 方向，假设

$$Y = \alpha X + N_Y,$$
$$N_X = (1 - \alpha\beta)X - \beta N_Y$$

独立，分以下情况.

(i) $(1 - \alpha\beta) \neq 0$ 且 $\beta \neq 0$. 定理 4.3 蕴含 X, N_Y、从而 Y, N_X 均正态分布，因此 $P_{X,Y}$ 也二元高斯.

(ii) $\beta = 0$. 此时 $X \perp\!\!\!\perp \alpha X + N_Y$，与引理 C.1 矛盾.

(iii) $(1 - \alpha\beta) = 0$. 有 $-\beta N_Y \perp\!\!\!\perp \alpha X + N_Y$，从而 $N_Y \perp\!\!\!\perp \alpha X + N_Y$，同样与该引理矛盾.

证明完毕. □

译注：源定理 *4.2* 未显式排除 $\alpha = 0$；若 $\alpha = 0$，情形 *(ii)* 并不与引理矛盾. 本证明在此使用引理还需 αX 非确定，其他退化边界也应另核. 译稿保留源定理及证明，不把该证明视为消除了前文记录的零系数疑点.

C.2 命题 6.3 的证明

证明： 回顾 SCM 定义要求底层图无环. 因此可以递归地将结构赋值互相代入，把每个节点 X_j 写为属于其祖先的全部噪声项 $(N_k)_{k \in \mathbf{AN}_j}$ 的唯一函数：

$$X_j := g_j\big((N_k)_{k \in \mathbf{AN}_j}\big).$$

函数未必依赖所有祖先的噪声项. □

译注：按第 *6.1* 节约定，祖先不包含节点自身，源式还须包含 N_j，例如无父节点的 $X_j := N_j$ 已说明这一点. 此处照录源式下标，不静默将祖先换成包含自身的集合.

C.3 注 6.6 的证明

证明： 证明：若能从 $\mathbf{PA}_j$ 移除一个变量，则在约化模型中仍能从 $\mathbf{PA}_j^*$ 移除它. 考虑 f_j 不依赖的输入 $X_k \in \mathbf{PA}_j \cap \mathbf{PA}_j^*$. 即对所有 $x_k, x_k', \mathbf{pa}_{j,-k}, n_j$，只要 $p(n_j) > 0$，都有

$$f_j(\mathbf{pa}_{j,-k}, x_k, n_j) = f_j(\mathbf{pa}_{j,-k}, x_k', n_j).$$

这里 $\mathbf{PA}_{j,-k} := \mathbf{PA}_j \setminus \{k\}$ 表示除 k 外的全部输入变量. g 也不依赖 x_k，因为对所有 $x_k, \mathbf{pa}_{j,-k}^*, n_j$，只要 $p(n_j) > 0$，就有

$$g(\mathbf{pa}_{j,-k}^*, x_k, n_j) = f_j(\mathbf{pa}_j, x_k, n_j).$$

□

译注：末式源文右侧写 $\mathbf{pa}_j$ 后又列 x_k，且将变量集合与下标 k 混用；此处忠实保留记号差异，不据此补定未给的参数约定.

C.4 命题 6.13 的证明

证明： 为简化记号，将 X, Y 分别写为 X_1, X_2. 截断分解公式 (6.9) 首先给出

$$\begin{aligned} p_{X_2}^{\mathfrak{C};do(X_1:=x_1)}(x_2) &= \int \prod_{j\neq 1} p_j(x_j \mid x_{pa(j)})\, dx_3 \cdots dx_d \\ &= \int \prod_{j\neq 1} p_j(x_j \mid x_{pa(j)}) \frac{\widetilde{p}(x_1)}{\widetilde{p}(x_1)}\, dx_3 \cdots dx_d \\ &= p_{X_2|X_1=x_1}^{\mathfrak{C};do(X_1:=\widetilde{N}_1)}(x_2), \end{aligned} \tag{C.1}$$

前提是 $\widetilde{N}_1$ 在 x_1 处有正质量，即 $\widetilde{p}(x_1) > 0$. 还要求对 (X_1, X_2) 上具有密度 q 的全部分布 Q_{X_1,X_2}，以下两条成立：

$$\begin{aligned} &X_2 \not\perp\!\!\!\perp X_1 (\text{在} Q \text{ 中}) \\ &\quad\Longleftrightarrow \exists x_1^{\triangle}, x_1^{\square} : q(x_1^{\triangle}), q(x_1^{\square}) > 0, \quad Q_{X_2|X_1=x_1^{\triangle}} \neq Q_{X_2|X_1=x_1^{\square}}, \end{aligned} \tag{C.2}$$

$$\begin{aligned} &X_2 \not\perp\!\!\!\perp X_1 (\text{在} Q \text{ 中}) \\ &\quad\Longleftrightarrow \exists x_1^{\triangle} : q(x_1^{\triangle}) > 0, \quad Q_{X_2|X_1=x_1^{\triangle}} \neq Q_{X_2}. \end{aligned} \tag{C.3}$$

对任意具有完全支撑的 $\widehat{N}_1$，于是有

(i) $\overset{(C.2)}{\Longrightarrow}$ $\exists x_1^{\triangle}, x_1^{\square}$ 在 $\widetilde{N}_1$ 下密度为正，使 $P_{X_2|X_1=x_1^{\triangle}}^{\mathfrak{C};do(X_1:=\widetilde{N}_1)} \neq P_{X_2|X_1=x_1^{\square}}^{\mathfrak{C};do(X_1:=\widetilde{N}_1)}$

$\overset{(C.1)}{\Longrightarrow}$ (ii)

$\overset{(C.1)}{\Longrightarrow}$ $\exists x_1^{\triangle}, x_1^{\square}$ 在 $\widehat{N}_1$ 下密度为正，使 $P_{X_2|X_1=x_1^{\triangle}}^{\mathfrak{C};do(X_1:=\widehat{N}_1)} \neq P_{X_2|X_1=x_1^{\square}}^{\mathfrak{C};do(X_1:=\widehat{N}_1)}$

$\overset{(C.2)}{\Longrightarrow}$ (iv) $\overset{\text{显然}}{\Longrightarrow}$ (i).

还显然有 (ii)⇒(iii)，并且 $P^{\mathfrak{C}}_{X_2} = P^{\mathfrak{C};do(X_1:=N_1^*)}_{X_2}$，其中 N_1^* 的分布为 $P^{\mathfrak{C}}_{X_1}$. 后者结合 ¬(i) ⇒ ¬(ii) 给出

$$
\begin{aligned}
\neg(\mathrm{i}) &\Longrightarrow X_2 \perp\!\!\!\perp X_1(\text{在} P^{\mathfrak{C};do(X_1:=N_1^*)}_{\mathbf{X}} \text{中}) \\
&\overset{(C.3)}{\Longrightarrow} P^{\mathfrak{C};do(X_1:=N_1^*)}_{X_2} = P^{\mathfrak{C};do(X_1:=N_1^*)}_{X_2|X_1=x^{\triangle}} \\
&\quad \text{对所有} x^{\triangle} \text{ 满足} p_1(x^{\triangle}) > 0 \\
&\overset{(C.1)}{\Longrightarrow} P^{\mathfrak{C};do(X_1:=x^{\triangle})}_{X_2} = P^{\mathfrak{C}}_{X_2} \\
&\quad \text{对所有} x^{\triangle} \text{ 满足} p_1(x^{\triangle}) > 0 \\
&\overset{\neg(\mathrm{ii})}{\Longrightarrow} P^{\mathfrak{C};do(X_1:=x^{\triangle})}_{X_2} = P^{\mathfrak{C}}_{X_2} \quad \forall x^{\triangle} \\
&\Longrightarrow \neg(\mathrm{iii}).
\end{aligned}
$$

符号 ¬ 表示陈述的否定. □

译注：源证明将连续变量密度为正也称为 “正质量”；连续点事件概率仍可能为零. 两个逐点条件分布刻画需适当版本及正则性，不能对任意在零测集上修改的条件分布无条件成立；保留源证明所明确要求的两条陈述. 命题 *6.13* 邻近译注的点零测集机制反例进一步表明：对任意可测 *SCM*，仅凭全支撑不能推出 *(iv)*，这不是仅选取一个条件分布版本便已解决的问题.

译注（同边缘随机化与混杂）：源证明还无条件断言 $P^{\mathfrak{C}}_{X_2} = P^{\mathfrak{C};do(X_1:=N_1^*)}_{X_2}$，此式一般错误. 取独立标准高斯 Z, N_X, N_Y，令 $X_1 := Z + N_X$、$X_2 := Z - X_1 + N_Y$. 观测下 $X_2 = -N_X + N_Y$ 的方差为 2；把 X_1 独立重采样为相同的 $N(0,2)$ 边缘后，X_2 的方差变为 $1 + 2 + 1 = 4$. 所有联合密度均非退化；保留干预变量自身的边缘并不保留其与混杂变量的依赖，也不保证下游边缘不变.

译注（*(iii)* 等价性的严格正反例）：令相互独立的 $N_Z \sim \mathrm{Ber}(1/2)$、$N_X, N_Y \sim \mathrm{Ber}(1/4)$，并令 $Z := N_Z$、$X := Z \oplus N_X$、$Y := Z \oplus X \oplus N_Y$，其中 $\oplus$ 为异或. 八个 (Z, X, Y) 联合单元的概率均为正，最小为 1/32. 对任一原子干预 $do(X := x)$，$Y \sim \mathrm{Ber}(1/2)$；对任意独立随机干预，给定每个有正概率的 $X = x$ 时仍如此，故 X, Y 独立，*(i)*、*(ii)* 为假. 然而观测下 $Y = N_X \oplus N_Y \sim \mathrm{Ber}(3/8)$，所以 *(iii)* 为真. 因而源命题的 *(iii)* 等价性在有混杂且有限严格正的情形也不成立，不能仅将上述等式看作尚缺论证的一步. 原命题及证明在此忠实照录；所需附加条件和原作者意图未知，不以译注补造缺失证明.

C.5 命题 6.14 的证明

证明： (i) 直接由干预 SCM 的 Markov 性得出. 干预移除进入 X 的边；若原图不存在从 X 到 Y 的有向路径，则二者 d 分离. (ii) 可由反例证明，例如例 6.34. □

C.6 命题 6.36 的证明

证明： “若”：假设不满足因果极小性，存在 X_j 与 $Y \in \mathbf{PA}_j^{\mathcal{G}}$，使从 $\mathcal{G}$ 移除边 $Y \to X_j$ 后，$P_{\mathbf{X}}$ 仍满足 Markov 性. 局部 Markov 性蕴含 $X_j \perp\!\!\!\perp Y \mid \mathbf{PA}_j^{\mathcal{G}} \setminus \{Y\}$.

“仅当”：若 $P_{\mathbf{X}}$ 有密度，Markov 条件等价于 Markov 分解［Lauritzen, 1996，定理 3.27］. 设 $Y \in \mathbf{PA}_j^{\mathcal{G}}$ 且 $X_j \perp\!\!\!\perp Y \mid \mathbf{PA}_j^{\mathcal{G}} \setminus \{Y\}$，则 $p(x_j \mid \mathbf{pa}_j^{\mathcal{G}}) = p(x_j \mid \mathbf{pa}_{j,-Y}^{\mathcal{G}})$，其中 $\mathbf{PA}_{j,-Y}^{\mathcal{G}} := \mathbf{PA}_j^{\mathcal{G}} \setminus \{Y\}$. 因而

$$p(\mathbf{x}) = p(x_j \mid \mathbf{pa}_{j,-Y}^{\mathcal{G}}) \prod_{k \neq j} p(x_k \mid \mathbf{pa}_k^{\mathcal{G}}),$$

说明 $P_{\mathbf{X}}$ 相对于删去 $Y \to X_j$ 的图满足 Markov 性. □

C.7 命题 6.48 的证明

证明： 假设两个模型均满足因果极小性，图分别为 $\mathcal{G}, \mathcal{H}$. 直观上，干预 X 后其子节点发生变化，因此可识别子节点；但例如两条路径相互抵消时，某些子节点的分布可能不变. 所以引入以下记号：给定 DAG $\mathcal{G}$，若 $X \in \mathbf{PA}_Y$，且 X 不是 Y 其他任何父节点的祖先，则称 X 为 Y 的一个最年轻父节点，记为 $X \in \mathbf{YPA}_Y$. Y 可有多个这样的父节点. 证明需要两个论断.

(i) 若 $X \in \mathbf{YPA}_Y^{\mathcal{G}}$，则 X 对 Y 有总因果效应，即存在 $x^{\triangle}, x^{\square}$ 使 $P_Y^{do(X:=x^{\triangle})} \neq P_Y^{do(X:=x^{\square})}$. 这由因果极小性得到.

(ii) 若 $Z \in \mathbf{AN}_Y^{\mathcal{G}}$，则存在 $X_1, \ldots, X_k$，满足 $X_1 = Z, X_k = Y$，并对 $i \in \{1, \ldots, k-1\}$ 有 $X_i \in \mathbf{YPA}_{X_{i+1}}^{\mathcal{G}}$.

结合两条：若 $Z \in \mathbf{AN}_Y^{\mathcal{G}}$，则存在 $X_1, \ldots, X_k$，使每个 X_i 对 X_{i+1} 都有总因果效应. 根据命题 6.13，$\mathcal{H}$ 中也必有 X_i 到 X_{i+1} 的有向因果路径，所以 $Z \in \mathbf{AN}_Y^{\mathcal{H}}$，两图有相同祖先关系. 因二者均满足因果极小性，得到 $\mathcal{G} = \mathcal{H}$，故两模型作为因果图模型等价. □

译注：此处保留源证明，不能把末句当作纯图论结论：祖先关系相同的 *DAG* 可以有不同的传递边，例如 $A \to B \to C$ 与额外含 $A \to C$ 的图. 从同祖先关系到图相同还需利用具体分布 / 干预假设的额外论证. 论断 *(i)* 也需核实从条件依赖到边缘干预分布变化的步骤；因果极小性本身只保证给定其他父节点时的依赖，不直接等于任意边缘效应非零. 这里不补造缺失证明.

C.8 命题 6.49 的证明

证明： 由命题 6.3 的证明，可将第一个 SCM 写为 $\mathbf{X} = g(\mathbf{N})$. 因为对所有 $p(\mathbf{n}) > 0$ 的 $\mathbf{n}$，有 $g(\mathbf{n}) = g^*(\mathbf{n})$，两 SCM 显然诱导相同观测分布（同样论证也给出相同干预分布）. 对反事实，以 $\mathbf{X} \in A$、$P(\mathbf{X} \in A) > 0$ 为条件，同时涵盖离散与连续情形，见定义 6.17.

新噪声密度满足

$$\begin{aligned}\widetilde{p}(n_1,\dots,n_d) &= \begin{cases} \dfrac{p(n_1,\dots,n_d)}{P(\mathbf{X}\in A)}, & g(n_1,\dots,n_d)\in A,\\ 0, & \text{否则},\end{cases}\\ &= \begin{cases} \dfrac{p(n_1,\dots,n_d)}{P(g(\mathbf{N})\in A)}, & g^*(n_1,\dots,n_d)\in A,\\ 0, & \text{否则},\end{cases}\\ &= \begin{cases} \dfrac{p(n_1,\dots,n_d)}{P(g^*(\mathbf{N})\in A)}, & g^*(n_1,\dots,n_d)\in A,\\ 0, & \text{否则},\end{cases}\\ &= \widetilde{p}^*(n_1,\dots,n_d).\end{aligned}$$

仍有对所有 $\widetilde{p}(\mathbf{n})>0$ 的 $\mathbf{n}$，$g(\mathbf{n})=g^*(\mathbf{n})$，所以全部反事实陈述一致. □

C.9 命题 7.1 的证明

证明： 取 $N_1,\dots,N_d$ 独立且在 0 与 1 之间均匀分布，定义 $X_j := f_j(X_{\mathbf{PA}_j}, N_j)$，其中

$$f_j(\mathbf{pa}_j, n_j) := F^{-1}_{X_j\mid \mathbf{PA}_j=\mathbf{pa}_j}(n_j). \tag{C.4}$$

右侧为给定 $\mathbf{PA}_j=\mathbf{pa}_j$ 时 X_j 的广义逆累积分布函数. 随机变量 Y 的广义逆定义为 $F_Y^{-1}(a) := \inf\{y\in\mathbb{R} : F_Y(y)\ge a\}$. 式 (C.4) 保证构造出的 SCM 中，条件分布 $X_j \mid \mathbf{PA}_j=\mathbf{pa}_j$ 正确. 结论由定义 6.21(iii) 的 Markov 分解得出. □

C.10 命题 7.4 的证明

证明： 假设不满足因果极小性，可找到节点 j 和 $i\in\mathbf{PA}_j$，使 $X_j = f_j(\mathbf{PA}_j\setminus\{i\}, X_i)+N_j$ 在给定其他全部父节点 $A := \mathbf{PA}_j\setminus\{i\}$ 时不依赖 X_i，即 $X_j \perp\!\!\!\perp X_i \mid X_A$，见命题 6.36. 这里用 X_A 表示 $\mathbf{PA}_j\setminus\{X_i\}$. 要证明对 P_{X_A,X_i} 几乎处处的 (x_A,x_i)，有 $f_j(x_A,x_i)=c_{x_A}$. 不失一般性地设 $E[N_j]=0$，则 $X_j\mid\mathbf{PA}_j=(x_A,x_i)$ 的均值为 $f_j(x_A,x_i)$. Dawid [1979] 的式 (2b) 指出，条件独立蕴含 $X_j\mid X_A,X_i$ 的密度不依赖 X_i 的参数，所以条件均值也不依赖 x_i，即 $f_j(x_A,x_i)=c_{x_A}$. 由连续性，f_j 的最后一个参数为常量. 逆向陈述也由命题 6.36 得出. □

译注：使用 $E[N_j]$ 须其存在；仅以平移作“不失一般性”不能解决不存在均值的噪声. 将几乎处处结论借连续性提升为逐点结论还依赖相应支撑条件；保留原命题的假设边界.

C.11 命题 8.1 的证明

证明： 使用 Bellman 最优性方程 [例如 Sutton 与 Barto, 2015, 第 3.8 节]. 对所有满足 $f(s^\circ) = f(s)$ 的 s°, s,

$$\begin{aligned}
Q^*(s,a) &= \sum_{s'} p(s' \mid s,a)\big(E[R \mid s',a] + \max_{a'} Q^*(s',a')\big) \\
&= \sum_{f'} \sum_{s':f(s')=f'} p(s' \mid s,a)\big(E[R \mid s',a] + \max_{a'} Q^*(s',a')\big) \\
&= \sum_{f'} p(f' \mid s,a)\big(E[R \mid f',a] + \max_{a'} Q^*(s',a')\big) \\
&= \sum_{f'} p(f' \mid s^\circ,a)\big(E[R \mid f',a] + \max_{a'} Q^*(s',a')\big) = Q^*(s^\circ,a).
\end{aligned}$$

证明完毕. □

译注：以上按源证明保留；第三、四行的 s' 已不再受求和约束. 将最优价值项从纤维内求和提出，需要先证明其在同一表示纤维上恒定，不能直接作为待证结论使用. 可通过满足相应奖励与转移条件的商过程及 *Bellman* 迭代另行论证，但本译稿不补造源证明缺口，也不将该显示推导认证为完整证明.

C.12 命题 8.2 的证明

证明： 第一个等式来自第 8.2.1 节的讨论. Markov 分解性质给出

$$p(\mathbf{x}) = p(a \mid s)p(s \mid h)p(h)p(y \mid f,h)p(f \mid a),$$

见图 8.5. 由 $F \perp\!\!\!\perp S \mid A$，有

$$\begin{aligned}
\int y \frac{\widetilde{p}(a \mid s)}{p(a \mid s)} p(\mathbf{x})\, d\mathbf{x} &= \int y \widetilde{p}(a \mid s)p(s \mid h)p(h)p(y \mid f,h)p(f \mid a,s)\, da\, df\, dh\, ds\, dy \\
&= \int y \widetilde{p}(f,a \mid s)p(s \mid h)p(h)p(y \mid f,h)\, da\, df\, dh\, ds\, dy \\
&= \int y \frac{\widetilde{p}(f \mid s)}{p(f \mid s)} p(s \mid h)p(h)p(y \mid f,h)p(f \mid s)\, df\, dh\, ds\, dy \\
&= \int y \frac{\widetilde{p}(f \mid s)}{p(f \mid s)} p(s \mid h)p(h)p(y \mid f,h)p(f,a \mid s)\, da\, df\, dh\, ds\, dy \\
&= \int y \frac{\widetilde{p}(f \mid s)}{p(f \mid s)} p(\mathbf{x})\, d\mathbf{x}.
\end{aligned}$$

最后一个等式来自 $p(f,a \mid s) = p(f \mid a,s)p(a \mid s)$. □

译注：比值重加权需要分母在目标分布支撑上非零及相应可积性；零概率动作或表示处不能直接作该除法.

C.13 命题 9.3 的证明

证明： 为证明 (i)，从 $\mathbf{X}$ 上的 SCM $\mathfrak{C}$ 及其诱导分布 $P_{\mathbf{X}}$ 出发. 考虑 $O \in \mathbf{O}$ 的结构赋值，每当右侧出现 $X \in \mathbf{X} \setminus \mathbf{O}$，便反复代入其赋值. 得到新 SCM，每个 O 的赋值含多元误差变量 $\widetilde{N}_O$. 显然小模型诱导相同 $P_{\mathbf{O}}$，也在干预任意 $O \in \mathbf{O}$ 时诱导相同干预分布. 因果充分性保证新噪声 $(\widetilde{N}_O)_{O\in\mathbf{O}}$ 联合独立. 与一维噪声情形（命题 6.31）一样，分布 $P_{\mathbf{O}}$ 相对于诱导图结构满足 Markov 性. 再用命题 7.1 的相同构造，将新模型转为一维误差的 SCM，保留观测与干预分布，即得结论. 更形式化的过程及论证细节见 Bongers 等 [2016]. (ii) 由例 9.2 得出. □

C.14 定理 10.3 的证明

证明： 若存在 $X^j_{\mathrm{past}(t)}$ 中某节点到 X^k_t 的箭头，则由忠实性立即得到式 (10.3)，因为直接相连的两个变量无法被 d 分离. 现在假设无此边，则给定 $\mathbf{X}^{-j}_{\mathrm{past}(t)}$ 时，X^k_t 与 $X^j_{\mathrm{past}(t)}$ d 分离：任何沿出边离开 X^k_t 的路径都被阻断，因为其中会有碰撞点，而时间下标大于等于 t 的后续节点均未取条件；任何沿入边离开它的路径也被阻断，因为下一个节点就在条件集 $\mathbf{X}^{-j}_{\mathrm{past}(t)}$ 中. □

C.15 定理 10.4 的证明

证明： 证明 (i)：考虑不含 $X \to Y$ 箭头的全时间图. $Y_{\mathrm{past}(t)}$ 阻断 Y_t 到 $X_{\mathrm{past}(t)}$ 的每条路径. 从 Y_t 出边开始的路径必须含条件集之外的碰撞点，且其后代也不在条件集中；从入边开始的路径，其第一个节点在 $Y_{\mathrm{past}(t)}$ 中，因而被阻断.

证明 (ii)：假设 Y_t 有来自 X 的父节点，记为 $\mathbf{PA}^X_{Y_t}$. 式 (10.5) 蕴含

$$Y_t \perp\!\!\!\perp \mathbf{PA}^X_{Y_t} \mid Y_{\mathrm{past}(t)}. \tag{C.5}$$

对任意 $X_s \in \mathbf{PA}^X_{Y_t}$，由弱并性（附录 A.1），

$$Y_t \perp\!\!\!\perp X_s \mid Y_{\mathrm{past}(t)} \cup (\mathbf{PA}^X_{Y_t} \setminus \{X_s\}). \tag{C.6}$$

据 Peters 等 [2014, 引理 38]，极小性蕴含：给定 Y_t 的任何非后代集合，只要其中含除了 A 外的全部其他父节点，Y_t 就依赖其任一父节点 A. 因而

$$Y_t \not\perp\!\!\!\perp X_s \mid Y_{\mathrm{past}(t)} \cup (\mathbf{PA}^X_{Y_t} \setminus \{X_s\}),$$

与式 (C.6) 矛盾. □

参考文献

Acid 与 de Campos 2003 S. Acid and L. M. de Campos. Searching for Bayesian network structures in the space of restricted acyclic partially directed graphs. Journal of Artificial Intelligence Research, 18:445–490, 2003.

Aldrich 1989 J. Aldrich. Autonomy. Oxford Economic Papers, 41:15–34, 1989.

Ali 2009 R. A. Ali, T. S. Richardson, and P. Spirtes. Markov equivalence for ancestral graphs. The Annals of Statistics, 37:2808–2837, 2009.

Allman 2009 E. S. Allman, C. Matias, and J. A. Rhodes. Identifiability of parameters in latent structure models with many observed variables. The Annals of Statistics, 37: 3099–3132, 2009.

Ancona 2004 N. Ancona, D. Marinazzo, and S. Stramaglia. Radial basis function approach to nonlinear Granger causality of time series. Physical Review E, 70:056221–1–7, 2004.

Andersson 2001 S. A. Andersson, D. Madigan, and M. D. Perlman. Alternative Markov property for chain graphs. Scandinavian Journal of Statistics, 28:33–86, 2001.

Aspect 1981 A. Aspect, P. Grangier, and G. Roger. Experimental tests of realistic local theories via Bell' s theorem. Physical Review Letters, 47:460–467, 1981.

Ay 2008 N. Ay and D. Polani. Information flows in causal networks. Advances in Complex Systems, 11(1):17–41, 2008.

Baldwin 等 1956 R. R. Baldwin, W. E. Cantey, H. Maisel, and J. P. McDermott. The optimum strategy in blackjack. Journal of the American Statistical Association, 51(275): 429–439, 1956.

Balke 1995 A. Balke. Probabilistic Counterfactuals: Semantics, Computation, Applications. PhD thesis, University of California, Los Angeles, CA, 1995.

Balke 与 Pearl 1997 A. Balke and J. Pearl. Bounds on treatment effects from studies with imperfect compliance. Journal of the American Statistical Association, 92:1172–1176, 1997.

Bareinboim 与 Pearl 2014 E. Bareinboim and J. Pearl. Transportability from multiple environments with limited experiments: Completeness results. In Advances in Neural Information Processing Systems 27 (NIPS), pages 280–288, 2014.

bareinboim2016 E. Bareinboim and J. Pearl. Causal inference from big data: Theoretical foundations and the data-fusion problem. Proceedings of the National Academy of Sciences, 113(27):7345–7352, 2016.

Bareinboim 等 2015 E. Bareinboim, A. Forney, and J. Pearl. Bandits with unobserved confounders: A causal approach. In Advances in Neural Information Processing Systems 28 (NIPS), pages 1342–1350, 2015.

bauer2016 S. Bauer, B. Schölkopf, and J. Peters. The arrow of time in multivariate time series. In Proceedings of the 33rd International Conference on Machine Learning (ICML), pages 2043–2051, 2016.

Bell 1964 J. Bell. On the Einstein-Podolsky-Rosen paradox. Physics, 1:195–200, 1964. Reprinted in J. Bell: Speakable and unspeakable in quantum mechanics, Cambridge University Press, Cambridge, UK, 1987.

Bellman 1957 R. Bellman. A Markovian decision process. Indiana University Mathematics Journal, 6:679–684, 1957.

Ben-David 等 2010 S. Ben-David, T. Lu, T. Luu, and D. Pál. Impossibility theorems for domain adaptation. In Proceedings of the International Conference on Artificial Intelligence and Statistics 13 (AISTATS), pages 129–136, 2010.

bennett1982 C. Bennett. The thermodynamics of computation — a review. International Journal of Theoretical Physics, 21:905–940, 1982.

Berger 1985 J. O. Berger. Statistical Decision Theory and Bayesian Analysis. Springer, New York, NY, 1985.

Berkson 1946 J. Berkson. Limitations of the application of fourfold table analysis to hospital data. Biometrics Bulletin, 2:47–53, 1946.

Besserve 等，准备中 M. Besserve, N. Shajarisales, D. Janzing, and B. Schölkopf. Causal inference through spectral independence in linear dynamical systems. in preparation.

Bhatt 2010 A. Bhatt. Evolution of clinical research: A history before and beyond James Lind. Perspectives in Clinical Research, 1(1):6–10, 2010.

Bollen 1989 K. A. Bollen. Structural Equations with Latent Variables. Wiley, New York, NY, 1989.

Bonet 2001 B. Bonet. Instrumentality tests revisited. In Proceedings of the 17th Conference on Uncertainty in Artificial Intelligence (UAI), pages 48–55, 2001.

Bongers 等 2016 S. Bongers, J. Peters, B. Schölkopf, and J. M. Mooij. Structural causal models: Cycles, marginalizations, exogenous reparametrizations and reductions. ArXiv e-prints (1611.06221), 2016.

Bottou 等 2013 L. Bottou, J. Peters, J. Quiñonero-Candela, D. X. Charles, D. M. Chickering, E. Portugualy, D. Ray, P. Simard, and E. Snelson. Counterfactual reasoning and learning systems: The example of computational advertising. Journal of Machine Learning Research, 14:3207–3260, 2013.

Bowden 与 Turkington 1990 R. J. Bowden and D. A. Turkington. Instrumental Variables. Econometric Society Monographs. Cambridge University Press, New York, NY, 1990.

Brito 2002a C. Brito and J. Pearl. A new identification condition for recursive models with correlated errors. Structural Equation Modeling, 9:459–474, 2002a.

Brito 与 Pearl 2002b C. Brito and J. Pearl. Generalized instrumental variables. In Proceedings of the 18th Conference on Uncertainty in Artificial Intelligence (UAI), pages 85–93, 2002b.

Brockwell 1991 P. J. Brockwell and R. A. Davis. Time Series: Theory and Methods. Springer, New York, NY, 2nd edition, 1991.

Bühlmann 与 van de Geer 2011 P. Bühlmann and S. A. van de Geer. Statistics for High-Dimensional Data: Methods, Theory and Applications. Springer Series in Statistics. Springer, New York, NY, 2011.

Bühlmann 等 2014 P. Bühlmann, J. Peters, and J. Ernest. CAM: Causal additive models, highdimensional order search and penalized regression. The Annals of Statistics, 42(6):2526–2556, 2014.

Buntine 1991 W. L. Buntine. Theory refinement on Bayesian networks. In In Proceedings of the 7th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 52–60, 1991.

Byrne 2007 R. M. J. Byrne. The Rational Imagination: How People Create Alternatives to Reality. MIT Press, Cambridge, MA, 2007.

Chaitin 1966 G. Chaitin. On the length of programs for computing finite binary sequences. Journal of the Assocation for Computing Machinery, 13(4):547–569, 1966.

Chapelle 等 2006 O. Chapelle, B. Schölkopf, and A. Zien. Semi-Supervised Learning. MIT Press, Cambridge, MA, 2006.

Charig 等 1986 C. R. Charig, D. R. Webb, S. R. Payne, and J. E. A. Wickham. Comparison of treatment of renal calculi by open surgery, percutaneous nephrolithotomy, and extracorporeal shockwave lithotripsy. British Medical Journal (Clin Res Ed), 292(6254):879–882, 1986.

Chaves 2014 R. Chaves, L. Luft, T. O. Maciel, D. Gross, D. Janzing, and B. Schölkopf. Inferring latent structures via information inequalities. In Proceedings of the 30th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 112– 121, 2014.

Chickering 1996 D. M. Chickering. Learning Bayesian networks is NP-complete. In Learning from Data: Artificial Intelligence and Statistics V, pages 121–130. Springer, New York, NY, 1996.

Chickering 2002 D. M. Chickering. Optimal structure identification with greedy search. Journal of Machine Learning Research, 3:507–554, 2002.

Claassen 2013 T. Claassen, J. M. Mooij, and T. Heskes. Learning sparse causal models is not NPhard. In Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 172–181, 2013.

Clauser 1969 J. Clauser, M. Horne, A. Shimony, and R. Holt. Proposed experiment to test local hidden-variable theories. Physical Review Letters, 23:880–884, 1969.

Colombo 2012 D. Colombo, M. H. Maathuis, M. Kalisch, and T. S. Richardson. Learning highdimensional directed acyclic graphs with latent and selection variables. The Annals of Statistics, 40:294–321, 2012.

Comley 与 Dowe 2003 J. Comley and D. Dowe. General Bayesian networks and asymmetric languages. In Proceedings of the 2nd Hawaii International Conference on Statistics and Related Fields, 2003.

comon1994 P. Comon. Independent component analysis — a new concept? Signal Processing, 36:287–314, 1994.

Cook 1971 S. A. Cook. The complexity of theorem-proving procedures. In Proceedings of the 3rd Annual ACM Symposium on Theory of Computing, pages 151–158, 1971.

Cooper 与 Yoo 1999 G. Cooper and C. Yoo. Causal discovery from a mixture of experimental and observational data. In Proceedings of the 15th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 116–125, 1999.

Corfield 2009 D. Corfield, B. Schölkopf, and V. Vapnik. Falsificationism and statistical learning theory: Comparing the Popper and Vapnik-Chervonenkis dimensions. Journal for General Philosophy of Science, 40(1):51–58, 2009.

Cover 与 Thomas 1991 T. Cover and J. Thomas. Elements of Information Theory. Wiley Series in Telecommunications and Signal Processing, Wiley, New York, NY, 1991.

Cox 1958 D. R. Cox. Planning of Experiments. Wiley, New York, NY, 1958.

Cussens 2011 J. Cussens. Bayesian network learning with cutting planes. In Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 153–160, 2011.

Daniušis 等 2010 P. Daniušis, D. Janzing, J. M. Mooij, J. Zscheischler, B. Steudel, K. Zhang, and B. Schölkopf. Inferring deterministic causal relations. In Proceedings of the 26th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 143–150, 2010.

Danks 2013 D. Danks and S. Plis. Learning causal structure from undersampled time series, 2013. URL http://repository.cmu.edu/cgi/viewcontent.cgi?article=1638&context=philosophy. Results were presented at NIPS 2013 workshop on causality; last visit of website: 31.01.2017.

darmois1953 G. Darmois. Analyse générale des liaisons stochastiques. Revue de l' Institut International de Statistique, 21:2–8, 1953.

Dash 2005 D. Dash. Restructing dynamic causal systems in equilibrium. In Proceedings of the 10th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 81–88, 2005.

dawid1979 A. P. Dawid. Conditional independence in statistical theory. Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion), 41(1): 1–31, 1979.

Dawid 2015 A. P. Dawid. Statistical causality from a decision-theoretic perspective. Annual Review of Statistics and Its Application, 2:273–303, 2015.

De Campos 与 Ji 2011 C. P. De Campos and Q. Ji. Efficient structure learning of Bayesian networks using constraints. Journal of Machine Learning Research, 12:663–689, 2011.

Devroye 等 1996 L. Devroye, L. Györfi, and G. Lugosi. A Probabilistic Theory of Pattern Recognition, volume 31 of Applications of Mathematics. Springer, New York, NY, 1996.

Didelez 等 2010 V. Didelez, S. Meng, and N. A. Sheehan. Assumptions of IV methods for observational epidemiology. Statistical Science, 25:22–40, 2010.

Diks 2006 C. Diks and V. Panchenko. A new statistic and practical guidelines for nonparametric Granger causality testing. Journal of Economic Dynamics and Control, 30(9–10):1647–1669, 2006.

divincenzo1995 D. DiVincenzo. Two-qubit gates are universal for quantum computation. Physical Review A, 51:1015–1022, 1995.

Drton 2009a M. Drton, M. Eichler, and T. S. Richardson. Computing maximum likelihood estimates in recursive linear models with correlated errors. Journal of Machine Learning Research, 10:2329–2348, 2009a.

Drton 2009b M. Drton, B. Sturmfels, and S. Sullivant. Lectures on Algebraic Statistics, volume 39 of Oberwolfach Seminars. Birkhäuser, Basel, 2009b.

Druzdzel 与 Simon 1993 M. Druzdzel and H. Simon. Causality in Bayesian belief networks. In In Proceedings of the 9th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 3–11, 1993.

Druzdzel 与 van Leijen 2001 M. J. Druzdzel and H. van Leijen. Causal reversibility in Bayesian networks. Journal of Experimental and Theoretical Artificial Intelligence, 13(1):45–62, 2001.

Dudley 2002 R. M. Dudley. Real Analysis and Probability. Cambridge University Press, New York, NY, 2002.

Eaton 与 Murphy 2007 D. Eaton and K. P. Murphy. Exact Bayesian structure learning from uncertain interventions. In Proceedings of the 11th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 107–114, 2007.

Eberhardt 与 Scheines 2007 F. Eberhardt and R. Scheines. Interventions and causal inference. Philosophy of Science, 74(5):981–995, 2007.

Eberhardt 等 2005 F. Eberhardt, C. Glymour, and R. Scheines. On the number of experiments sufficient and in the worst case necessary to identify all causal relations among n variables. In Proceedings of the 21st Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 178–184, 2005.

Eberhardt 等 2010 F. Eberhardt, P. O. Hoyer, and R. Scheines. Combining experiments to discover linear cyclic models with latent variables. In Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 185–192, 2010.

Eichler 2011 M. Eichler. Graphical modelling of multivariate time series. Probability Theory and Related Fields, pages 1–36, 2011.

Eichler 2012 M. Eichler. Causal inference in time series analysis. In C. Berzuini, P. Dawid, and L. Bernardinelli, editors, Causality: Statistical Perspectives and Applications, pages 327–354. Wiley, Chichester, UK, 2012.

Ellenberg 2014 J. Ellenberg. How Not to Be Wrong: The Power of Mathematical Thinking. Penguin Press, London, UK, 2014.

engle1983 R. F. Engle, D. F. Hendry, and J.-F. Richard. Exogeneity. Econometrica, 51(2): 277–304, 1983.

Evans 2012 R. J. Evans. Graphical methods for inequality constraints in marginalized DAGs. In Proceedings of the 22nd Workshop on Machine Learning and Signal Processing, pages 1–12, 2012.

Evans 2015 R. J. Evans. Margins of discrete Bayesian networks. ArXiv e-prints (arXiv:1501.02103), 2015.

Evans 2014 R. J. Evans and T. S. Richardson. Markovian acyclic directed mixed graphs for discrete data. The Annals of Statistics, 42(2):1452–1482, 2014.

Ferguson 1967 T. S. Ferguson. Mathematical Statistics — A Decision Theoretic Approach. Academic Press, New York, NY and London, UK, 1967.

Fink 2011 A. Fink. The binomial ideal of the intersection axiom for conditional probabilities. Journal of Algebraic Combinatorics, 33(3):455–463, 2011.

Fisher 1925 R. A. Fisher. Statistical Methods for Research Workers. Oliver & Boyd, Edinburgh, UK, 1925.

Freeman 1994 W. T. Freeman. The generic viewpoint assumption in a framework for visual perception. Nature, 368(6471):542–545, 1994.

frisch1933 R. Frisch and F. V. Waugh. Partial time regressions as compared with individual trends. Econometrica, 1(4):387–401, 1933.

frisch1948 R. Frisch, T. Haavelmo, T. C. Koopmans, and J. Tinbergen. Autonomy of Economic Relations. Series: Memorandum fra Universitets Socialøkonomiske Institutt. Universitets Socialøkonomiske Institutt, Oslo, Norway, 1948.

Friston 2003 K. Friston, L. Harrison, and W. Penny. Dynamic causal modelling. NeuroImage, 19:1273–1302, 2003.

Friston 2013 K. Friston, J. Daunizeau, and K. Stephan. Model selection and gobbledygook: Response to Lohmann et al. NeuroImage, 75:275–278, 2013.

Frydenberg 1990 M. Frydenberg. The chain graph Markov property. Scandinavian Journal of Statistics, 17(4):333–353, 1990.

Fukumizu 等 2008 K. Fukumizu, A. Gretton, X. Sun, and B. Schölkopf. Kernel measures of conditional dependence. In Advances in Neural Information Processing Systems 20 (NIPS), pages 489–496, 2008.

Gagnon-Bartsch 与 Speed 2012 J. A. Gagnon-Bartsch and T. P. Speed. Using control genes to correct for unwanted variation in microarray data. Biostatistics, 13:539–552, 2012.

Galles 与 Pearl 1998 D. Galles and J. Pearl. An axiomatic characterization of causal counterfactuals. Foundations of Science, 3(1):151–182, 1998.

Geiger 与 Heckerman 1994a D. Geiger and D. Heckerman. Learning Gaussian networks. In Proceedings of the 10th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 235–243, 1994a.

Geiger 与 Heckerman 1994b D. Geiger and D. Heckerman. Learning Bayesian networks: The combination of knowledge and statistical data. In Proceedings of the 10th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 293–301, 1994b.

Geiger 1998 D. Geiger and C. Meek. Graphical models and exponential families. In Proceedings of 14th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 156–165, 1998.

Geiger 2014 P. Geiger, D. Janzing, and B. Schölkopf. Estimating causal effects by bounding confounding. In Proceedings of the 30th Conference on Uncertainty in Artificial Intelligence (UAI), pages 240–249, 2014.

Geradin 与 Girgenson 2011 D. Geradin and I. Girgenson. The counterfactual method in EU competition law: The cornerstone of the effects-based approach. Available at SSRN: http://ssrn.com/abstract=1970917, 2011.

Granger 1980 C. W. J. Granger. Testing for causality: A personal viewpoint. Journal of Economic Dynamics and Control, 2(1):329–352, 1980.

Granger 1988 C. W. J. Granger. Some recent development in a concept of causality. Journal of Econometrics, 39(1–2):199–211, 1988.

Gretton 等 2008 A. Gretton, K. Fukumizu, C. H. Teo, L. Song, B. Schölkopf, and A. Smola. A kernel statistical test of independence. In Advances in Neural Information Processing Systems 20 (NIPS), pages 585–592, 2008.

Grünwald 2007 P. D. Grünwald. The Minimum Description Length Principle. MIT Press, Cambridge, MA, 2007.

Guyon 2013 I. Guyon. Challenge: Cause-effect pairs, 2013. URL https://www.kaggle.com/c/cause-effect-pairs/. Results were presented at NIPS 2013 workshop http://clopinet.com/isabelle/Projects/NIPS2013/; last visit of websites: 19.07.2016.

Gwiazda 等 2000 J. Gwiazda, E. Ong, R. Held, and F. Thorn. Vision: Myopia and ambient night-time lighting. Nature, 404:144, 2000.

haavelmo1943 T. Haavelmo. The statistical implications of a system of simultaneous equations. Econometrica, 11(1):1–12, 1943.

haavelmo1944 T. Haavelmo. The probability approach in econometrics. Econometrica, 12:S1– S115 (supplement), 1944.

Halpern 2000 J. Y. Halpern. Axiomatizing causal reasoning. Journal of Artificial Intelligence Research, 12:317–337, 2000.

Halpern 2016 J. Y. Halpern. Actual Causality. MIT Press, Cambridge, MA, 2016.

Hansen 与 Sokol 2014 N. R. Hansen and A. Sokol. Causal interpretation of stochastic differential equations. Electronic Journal of Probability, 19(100):1–24, 2014.

Hastie 等 2009 T. Hastie, R. Tibshirani, and J. Friedman. The Elements of Statistical Learning: Data Mining, Inference and Prediction. Springer, New York, NY, 2nd edition, 2009.

Haughton 1988 D. M. A. Haughton. On the choice of a model to fit data from an exponential family. The Annals of Statistics, 16(1):342–355, 1988.

Hauser 与 Bühlmann 2012 A. Hauser and P. Bühlmann. Characterization and greedy learning of interventional Markov equivalence classes of directed acyclic graphs. Journal of Machine Learning Research, 13:2409–2464, 2012.

Hauser 与 Bühlmann 2014 A. Hauser and P. Bühlmann. Two optimal strategies for active learning of causal models from interventional data. International Journal of Approximate Reasoning, 55:926–939, 2014.

Hauser 与 Bühlmann 2015 A. Hauser and P. Bühlmann. Jointly interventional and observational data: Estimation of interventional Markov equivalence classes of directed acyclic graphs. Journal of the Royal Statistical Society, Series B: Statistical Methodology, 77: 291–318, 2015.

hausman1999 D. M. Hausman and J. Woodward. Independence, invariance and the causal Markov condition. The British Society for the Philosophy of Science, 50:521– 583, 1999.

heckerman1999 D. Heckerman, C. Meek, and G. Cooper. A Bayesian approach to causal discovery. In C. Glymour and G. Cooper, editors, Computation, Causation, and Discovery, pages 141–165. MIT Press, Cambridge, MA, 1999.

Hemmecke 等 2012 R. Hemmecke, S. Linder, and M. Studený. Characteristic imsets for learning Bayesian network structure. International Journal of Approximate Reasoning, 53:1336–1349, 2012.

Hernán 与 Robins 2006 M. A. Hernán and J. M. Robins. Instruments for causal inference: An epidemiologists dream? Epidemiology, 17:360–372, 2006.

Holland 1986 P. W. Holland. Statistics and causal inference. Journal of the American Statistical Association, 81:968–970, 1986.

Hoover 2008 K. D. Hoover. Causality in economics and econometrics. In S. N. Durlauf and L. E. Blume, editors, The New Palgrave Dictionary of Economics. Palgrave Macmillan, Basingstoke, UK, 2nd edition, 2008.

Horvitz 与 Thompson 1952 D. G. Horvitz and D. J. Thompson. A generalization of sampling without replacement from a finite universe. Journal of the American Statistical Association, 47 (260):663–685, 1952.

hoyer2008a P. O. Hoyer, A. Hyvärinen, R. Scheines, P. Spirtes, J. Ramsey, G. Lacerda, and S. Shimizu. Causal discovery of linear acyclic models with arbitrary distributions. In Proceedings of the 24th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 282–289, 2008a.

Hoyer 2008b P. O. Hoyer, S. Shimizu, A. J. Kerminen, and M. Palviainen. Estimation of causal effects using linear non-Gaussian causal models with hidden variables. International Journal of Approximate Reasoning, 49(2):362–378, 2008b.

hoyer2009 P. O. Hoyer, D. Janzing, J. M. Mooij, J. Peters, and B. Schölkopf. Nonlinear causal discovery with additive noise models. In Advances in Neural Information Processing Systems 21 (NIPS), pages 689–696, 2009.

Huang 与 Valtorta 2006 Y. Huang and M. Valtorta. Pearl' s calculus of intervention is complete. In Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 217–224, 2006.

hurwicz1962 L Hurwicz. On the structural form of interdependent systems. In E. Nagel, P. Suppes, and A. Tarski, editors, Logic, Methodology and Philosophy of Science, Proceedings of the 1960 International Congress, pages 232–239. Stanford University Press, Stanford, CA, 1962.

hyttinen2012 A. Hyttinen, F. Eberhardt, and P. O. Hoyer. Learning linear cyclic causal models with latent variables. Journal of Machine Learning Research, 13(1):3387–3439, 2012.

Hyttinen 等 2013 A. Hyttinen, P. O. Hoyer, F. Eberhardt, and M. Järvisalo. Discovering cyclic causal models with latent variables: A general SAT-based procedure. In Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 301–310, 2013.

Hyttinen 2016 A. Hyttinen, S. Plis, M. Järvisalo, F. Eberhardt, and D. Danks. Causal discovery from subsampled time series data by constraint optimization. In Proceedings of the 8th International Conference on Probabilistic Graphical Models (PGM), pages 216–227, 2016.

Hyvärinen 等 2001 A. Hyvärinen, J. Karhunen, and E. Oja. Independent Component Analysis. Adaptive and Learning Systems for Signal Processing, Communications, and Control. Wiley, New York, NY, 2001.

Hyvärinen 2008 A. Hyvärinen, S. Shimizu, and P. Hoyer. Causal modelling combining instantaneous and lagged effects: An identifiable model based on non-Gaussianity. In Proceedings of the 25th International Conference on Machine Learning (ICML), pages 424–431, 2008.

Imbens 与 Angrist 1994 G. W. Imbens and J. Angrist. Identification and estimation of local average treatment effects. Econometrica, 62(2):467–75, 1994.

Imbens 与 Rubin 1995 G. W. Imbens and D. B. Rubin. Discussion of: "Causal Diagrams for Empirical Research" by J. Pearl. Biometrika, 82(4):694–695, 1995.

Imbens 与 Rubin 2015 G. W. Imbens and D. B. Rubin. Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction. Cambridge University Press, New York, NY, 2015.

Jaakkola 等 2010 T. Jaakkola, D. Sontag, A. Globerson, and M. Meila. Learning Bayesian network structure using LP relaxations. Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 358–365, 2010.

Jacob 等 2016 L. Jacob, J. A. Gagnon-Bartsch, and T. P. Speed. Correcting gene expression data when neither the unwanted variation nor the factor of interest are observed. Biostatistics, 17(1):16–28, 2016.

janzing2010entropy D. Janzing. On the entropy production of time series with unidirectional linearity. Journal of Statistical Physics, 138:767–779, 2010.

janzing2010 D. Janzing and B. Schölkopf. Causal inference using the algorithmic Markov condition. IEEE Transactions on Information Theory, 56(10):5168–5194, 2010.

Janzing 与 Schölkopf 2015 D. Janzing and B. Schölkopf. Semi-supervised interpolation in an anticausal learning scenario. Journal of Machine Learning Research, 16:1923–1948, 2015.

Janzing 与 Steudel 2010 D. Janzing and B. Steudel. Justifying additive-noise-based causal discovery via algorithmic information theory. Open Systems and Information Dynamics, 17 (2):189–212, 2010.

Janzing 2009a D. Janzing, J. Peters, J. M. Mooij, and B. Schölkopf. Identifying confounders using additive noise models. In Proceedings of the 25th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 249–257, 2009a.

Janzing 等 2009b D. Janzing, X. Sun, and B. Schölkopf. Distinguishing cause and effect via second order exponential models. ArXiv e-prints (0910.5561), 2009b.

Janzing 等 2010 D. Janzing, P. O. Hoyer, and B. Schölkopf. Telling cause from effect based on highdimensional observations. In Proceedings of the 27th International Conference on Machine Learning (ICML), pages 479–486, 2010.

Janzing 2011 D. Janzing, E. Sgouritsa, O. Stegle, J. Peters, and B. Schölkopf. Detecting lowcomplexity unobserved causes. In Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 383–391, 2011.

Janzing 等 2012 D. Janzing, J. M. Mooij, K. Zhang, J. Lemeire, J. Zscheischler, P. Daniušis, B. Steudel, and B. Schölkopf. Information-geometric approach to inferring causal directions. Artificial Intelligence, 182–183:1–31, 2012.

Janzing 2013 D. Janzing, D. Balduzzi, M. Grosse-Wentrup, and B. Schölkopf. Quantifying causal influences. The Annals of Statistics, 41(5):2324–2358, 2013.

Janzing 等 2015 D. Janzing, B. Steudel, N. Shajarisales, and B. Schölkopf. Justifying informationgeometric causal inference. In V. Vovk, H. Papadopolous, and A. Gammerman, editors, Measures of Complexity, Festschrift for Alexey Chervonencis, pages 253–265. Springer, Heidelberg, Germany, 2015.

janzing2016 D. Janzing, R. Chaves, and B. Schölkopf. Algorithmic independence of initial condition and dynamical law in thermodynamics and causal inference. New Journal of Physics, 18(093052):1–13, 2016.

Kääriäinen 2005 M. Kääriäinen. Generalization error bounds using unlabeled data. In Proceedings of the 18th Annual Conference on Learning Theory (COLT), pages 127–142, 2005.

Kalisch 与 Bühlmann 2007 M. Kalisch and P. Bühlmann. Estimating high-dimensional directed acyclic graphs with the PC-algorithm. Journal of Machine Learning Research, 8:613–636, 2007.

Kalisch 等 2012 M. Kalisch, M. Mächler, D. Colombo, M. H. Maathuis, and P. Bühlmann. Causal inference using graphical models with the R package pcalg. Journal of Statistical Software, 47(11):1–26, 2012.

Kang 2006 C. Kang and J. Tian. Inequality constraints in causal models with hidden variables. In Proceedings of the 22th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 233–240, 2006.

kano2003 Y. Kano and S. Shimizu. Causal inference using nonnormality. In Proceedings of the International Symposium on the Science of Modeling, the 30th Anniversary of the Information Criterion, pages 261–270, 2003.

Kela 2017 A. Kela, K. von Prillwitz, J. Åberg, R. Chaves, and D. Gross. Semidefinite tests for latent causal structures. ArXiv e-prints (1701.00652), 2017.

Koivisto 2006 M. Koivisto. Advances in exact Bayesian structure discovery in Bayesian networks. In Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 241–248, 2006.

Koivisto 与 Sood 2004 M. Koivisto and K. Sood. Exact Bayesian structure discovery in Bayesian networks. Journal of Machine Learning Research, 5:549–573, 2004.

Koller 与 Friedman 2009 D. Koller and N. Friedman. Probabilistic Graphical Models: Principles and Techniques. MIT Press, Cambridge, MA, 2009.

Kolmogorov 1965 A. Kolmogorov. Three approaches to the quantitative definition of information. Problems of Information Transmission, 1(1):3–11, 1965.

koopmans1950 T. C. Koopmans. When is an equation system complete for statistical purposes? In T. C. Koopmans, editor, Statistical Inference in Dynamic Economic Models, pages 393–409. Wiley and Chapman & Hall, New York, NY, and London, UK, 1950.

Korb 等 2004 K. Korb, L. Hope, A. Nicholson, and K. Axnick. Varieties of causal intervention. In Proceedings of the Pacific Rim Conference on Artifical Intelligence, pages 322–331, 2004.

Kpotufe 等 2014 S. Kpotufe, E. Sgouritsa, D. Janzing, and B. Schölkopf. Consistency of causal inference under the additive noise model. In Proceedings of the 31st International Conference on Machine Learning, ICML 2014, Beijing, China, pages 478–486, 2014.

lacerda2008 G. Lacerda, P. Spirtes, J. Ramsey, and P. O. Hoyer. Discovering cyclic causal models by independent components analysis. In Proceedings of the 24th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 366–374, 2008.

Lauritzen 1996 S. L. Lauritzen. Graphical Models. Oxford University Press, New York, NY, 1996.

Lauritzen 2004 S. L. Lauritzen. Discussion on causality. Scandinavian Journal of Statistics, 31(2): 189–193, 2004.

lauritzen2002 S. L. Lauritzen and T. S. Richardson. Chain graph models and their causal interpretations. Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion), 64(3):321–361, 2002.

Lauritzen 1989 S. L. Lauritzen and N. Wermuth. Graphical models for associations between variables, some of which are qualitative and some quantitative. Annals of Statistics, 17(1):31–57, 1989.

lemeire2006 J. Lemeire and E. Dirkx. Causal models as minimal descriptions of multivariate systems. http://parallel.vub.ac.be/~jan/, 2006.

Lemeire 与 Janzing 2013 J. Lemeire and D. Janzing. Replacing causal faithfulness with algorithmic independence of conditionals. Minds and Machines, 23:227–249, 2013.

Levin 1973 L. A. Levin. Universal sequential search problems. Problems of Information Transmission, 9(3):115–116, 1973. (Translated into English by B. A. Trakhtenbrot: "A survey of Russian approaches to perebor (brute-force searches) algorithms," Annals of the History of Computing 6(4): 384–400, 1984).

Levine 2011 M. Levine, D. R. Hunter, and D. Chauveau. Maximum smoothed likelihood for multivariate mixtures. Biometrika, 98(2):403–416, 2011.

Li 与 Vitányi 1997 M. Li and P. Vitányi. An Introduction to Kolmogorov Complexity and Its Applications. Springer, New York, NY, 3rd edition, 1997. 译注：源书同时列第三版与 *1997* 年，版次和年份的对应尚未另核，元数据照源保留.

Lohmann 2012a G. Lohmann, K. Erfurth, K. Müller, and R. Turner. Critical comments on dynamic causal modelling. NeuroImage, 59:2322–2329, 2012a.

Lohmann 2012b G. Lohmann, K. Müller, and R. Turner. Response to commentaries on our paper: Critical comments on dynamic modeling. NeuroImage, 75:279–281, 2012b.

Lopez-Paz 等 2015 D. Lopez-Paz, K. Muandet, B. Schölkopf, and I. Tolstikhin. Towards a learning theory of cause-effect inference. In Proceedings of the 32nd International Conference on Machine Learning (ICML), pages 1452–1461, 2015.

Lütkepohl 2007 H. Lütkepohl. New Introduction to Multiple Time Series Analysis. Springer, Berlin, Germany, 2007.

Maathuis 等 2009 M. H. Maathuis, D. Colombo, M. Kalisch, and P. Bühlmann. Estimating highdimensional intervention effects from observational data. The Annals of Statistics, 37(6A):3133–3164, 2009.

MacKay 2002 D. J. C. MacKay. Information Theory, Inference, and Learning Algorithms. Cambridge University Press, New York, NY, 2002.

Mani 2006 S. Mani, G. F. Cooper, and P. Spirtes. A theoretical study of y structures for causal discovery. In Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 314–323, 2006.

Marinazzo 2008 D. Marinazzo, M. Pellicoro, and S. Stramaglia. Kernel method for nonlinear Granger causality. Physical Review Letters, 100:144103–1–4, 2008.

Markowetz 等 2005 F. Markowetz, S. Grossmann, and R. Spang. Probabilistic soft interventions in conditional Gaussian networks. In Proceedings of the 10th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 214–221, 2005.

marschak1950 J. Marschak. Statistical inference in economics: An introduction. In T. C. Koopmans, editor, Statistical Inference in Dynamic Economic Models, pages 1–50. Wiley and Chapman & Hall, New York, NY, and London, UK, 1950. Cowles Commission for Research in Economics, Monograph No. 10.

McKay 2004 B. D. McKay. Acyclic digraphs and eigenvalues of (0, 1)–matrices. Journal of Integer Sequences, 7(2):1–5, 2004.

Meek 1995 C. Meek. Causal inference and causal explanation with background knowledge. In Proceedings of the 11th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 403–441, 1995.

Mooij 等 2009 J. M. Mooij, D. Janzing, J. Peters, and B. Schölkopf. Regression by dependence minimization and its application to causal inference. In Proceedings of the 26th International Conference on Machine Learning (ICML), pages 745–752, 2009.

Mooij 等 2011 J. M. Mooij, D. Janzing, T. Heskes, and B. Schölkopf. On causal discovery with cyclic additive noise models. In Advances in Neural Information Processing Systems 24 (NIPS), pages 639–647, 2011.

Mooij 等 2013 J. M. Mooij, D. Janzing, and B. Schölkopf. From ordinary differential equations to structural causal models: The deterministic case. In Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 440– 448, 2013.

mooij2016 J. M. Mooij, J. Peters, D. Janzing, J. Zscheischler, and B. Schölkopf. Distinguishing cause from effect using observational data: methods and benchmarks. Journal of Machine Learning Research, 17:1–102, 2016.

Morgan 与 Winship 2007 S. L. Morgan and C. Winship. Counterfactuals and Causal Inference: Methods and Principles for Social Research. Cambridge University Press, New York, NY, 2nd edition, 2007.

Newey 2013 W. K. Newey. Nonparametric instrumental variables estimation. American Economic Review, 103(3):550–556, 2013.

Neyman 1923 J. Neyman. On the application of probability theory to agricultural experiments. Essay on principles. Section 9 (translated). Statistical Science, 5:465–480, 1923.

nielsen2000 M. Nielsen and I. Chuang. Quantum Computation and Quantum Information. Cambridge University Press, New York, NY, 2000.

Nowzohour 与 Bühlmann 2016 C. Nowzohour and P. Bühlmann. Score-based causal learning in additive noise models. Statistics, 50(3):471–485, 2016.

Nowzohour 2015 C. Nowzohour, M. Maathuis, and P. Bühlmann. Structure learning with bow-free acyclic path diagrams. ArXiv e-prints (1508.01717), 2015.

OEIS Foundation Inc. 2017 OEIS Foundation Inc. The on-line encyclopedia of integer sequences. http://oeis.org/A003024, 2017. last visit of website: 05.09.2016.

Pearl 1985 J. Pearl. A constraint propagation approach to probabilistic reasoning. In Proceedings of the 4th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 31–42, 1985.

Pearl 1988 J. Pearl. Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. Morgan Kaufmann Publishers Inc., San Francisco, CA, 1988.

Pearl 1993 J. Pearl. Belief networks revisited. Artificial Intelligence, 59:49–56, 1993.

Pearl 1995 J. Pearl. Causal diagrams for empirical research. Biometrika, 82(4):669–688, 1995.

Pearl 2009 J. Pearl. Causality: Models, Reasoning, and Inference. Cambridge University Press, New York, NY, 2nd edition, 2009.

pearl2015 J. Pearl. Trygve Haavelmo and the emergence of causal calculus. Econometric Theory, 31:152–179, 2015.

Pearl 等 2016 J. Pearl, M. Glymour, and N. P. Jewell. Causal Inference in Statistics. Wiley, New York, NY, 2016.

Peirce 1883 C. S. Peirce. A theory of probable inference. In C. S. Peirce, editor, Studies in Logic by Members of the Johns Hopkins University, pages 126–181. Little, Brown, and Company, Boston, MA, 1883.

Peirce 与 Jastrow 1885 C. S. Peirce and J. Jastrow. On small differences in sensation. Memoirs of the National Academy of Sciences, 3:73–83, 1885.

Perkovic 等 2015 E. Perkovic, J. Textor, M. Kalisch, and M. Maathuis. A complete generalized adjustment criterion. In Proceedings of the 31st Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 682–691, 2015.

Peters 2008 J. Peters. Asymmetries of time series under inverting their direction. Diploma Thesis, University of Heidelberg, Heidelberg, Germany, 2008.

Peters 2012 J. Peters. Restricted Structural Equation Models for Causal Inference. PhD thesis, ETH Zurich and MPI for Intelligent Systems, 2012. http://dx.doi.org/10.3929/ethz-a-007597940.

Peters 2014 J. Peters. On the intersection property of conditional independence and its application to causal discovery. Journal of Causal Inference, 3:97–108, 2014.

Peters 与 Bühlmann 2014 J. Peters and P. Bühlmann. Identifiability of Gaussian structural equation models with equal error variances. Biometrika, 101(1):219–228, 2014.

Peters 与 Bühlmann 2015 J. Peters and P. Bühlmann. Structural intervention distance (SID) for evaluating causal graphs. Neural Computation, 27:771–799, 2015.

Peters 等 2009a J. Peters, D. Janzing, A. Gretton, and B. Schölkopf. Kernel methods for detecting the direction of time series. In Proccedings of the 32nd Annual Conference of the German Classification Society (GfKl 2008), pages 1–10, 2009a.

peters2009b J. Peters, D. Janzing, A. Gretton, and B. Schölkopf. Detecting the direction of causal time series. In Proceedings of the 26th International Conference on Machine Learning (ICML), pages 801–808, 2009b.

Peters 等 2010 J. Peters, D. Janzing, and B. Schölkopf. Identifying cause and effect on discrete data using additive noise models. In Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 597–604, 2010.

Peters 等 2011a J. Peters, D. Janzing, and B. Schölkopf. Causal inference on discrete data using additive noise models. IEEE Transactions on Pattern Analysis and Machine Intelligence, 33:2436–2450, 2011a.

peters2011b J. Peters, J. M. Mooij, D. Janzing, and B. Schölkopf. Identifiability of causal graphs using functional models. In Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 589–598, 2011b.

Peters 2013 J. Peters, D. Janzing, and B. Schölkopf. Causal inference on time series using restricted structural equation models. In Advances in Neural Information Processing Systems 26 (NIPS), pages 154–162, 2013.

Peters 等 2014 J. Peters, J. M. Mooij, D. Janzing, and B. Schölkopf. Causal discovery with continuous additive noise models. Journal of Machine Learning Research, 15:2009– 2053, 2014.

Peters 等 2016 J. Peters, P. Bühlmann, and N. Meinshausen. Causal inference using invariant prediction: identification and confidence intervals. Journal of the Royal Statistical Society, Series B: Statistical Methodology (with discussion), 78(5):947–1012, 2016.

Peterson 2005 K. Peterson. Night light with sleep timer, 2005. URL http://www.google.com/patents/US20050007889. US Patent App. 10/614,245; last visit of website: 19.07.2016.

Pfister 等 2017 N. Pfister, P. Bühlmann, B. Schölkopf, and J. Peters. Kernel-based tests for joint independence. Journal of the Royal Statistical Society: Series B (to appear), 2017. doi: 10.1111/rssb.12235.

Popper 2002 K. R. Popper. The Logic of Scientific Discovery. Routledge, London, 2002. 1st English Edition: 1959.

Quinn 等 1999 G. E. Quinn, C. H. Shin, M. G. Maguire, and R. A. Stone. Myopia and ambient lighting at night. Nature, 399:113–114, 1999.

Quionero-Candela 等 2009 J. Quionero-Candela, M. Sugiyama, A. Schwaighofer, and N. D. Lawrence. Dataset Shift in Machine Learning. MIT Press, Cambridge, MA, 2009.

R Core Team 2016 R Core Team. R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria, 2016. URL http://www.R-project.org.

Ramsey 2014 J. Ramsey. A scalable conditional independence test for nonlinear, non-Gaussian data. ArXiv e-prints (1401.5031), 2014.

Reichenbach 1956 H. Reichenbach. The Direction of Time. University of California Press, Berkeley, CA, 1956.

Richardson 2003 T. S. Richardson. Markov properties for acyclic directed mixed graphs. Scandinavian Journal of Statistics, 30(1):145–157, 2003.

Richardson 与 Robins 2013 T. S. Richardson and J. M. Robins. Single world intervention graphs (SWIGs): A unification of the counterfactual and graphical approaches to causality, 2013. Working Paper Number 128, Center for Statistics and the Social Sciences, University of Washington.

Richardson 2002 T. S. Richardson and P. Spirtes. Ancestral graph Markov models. The Annals of Statistics, 30(4):962–1030, 2002.

Richardson 2012 T. S. Richardson, J. M. Robins, and I. Shpitser. Nested Markov properties for acyclic directed mixed graphs (abstract only). In Proceedings of the 28th Annual Conference on Uncertainty in Artificial Intelligence (UAI), 2012.

Richardson 2017 T. S. Richardson, R. J. Evans, J. M. Robins, and I. Shpitser. Nested Markov properties for acyclic directed mixed graphs. ArXiv e-prints (1701.06686), 2017.

Robins 1986 J. M. Robins. A new approach to causal inference in mortality studies with sustained exposure periods — applications to control of the healthy worker survivor effect. Mathematical Modeling, 7:1393–1512, 1986.

Robins 等 2003 J. M. Robins, R. Scheines, P. Spirtes, and L. Wasserman. Uniform consistency in causal inference. Biometrika, 90(3):491–515, 2003.

Robinson 1970 R. W. Robinson. Enumeration of acyclic digraphs. In Proceedings of the 2nd Chapel Hill Conference on Combinatorial Mathematics and its Applications (University of North Carolina), pages 391–399, 1970.

Robinson 1973 R. W. Robinson. Counting labeled acyclic digraphs. In F. Harary, editor, New Directions in the Theory of Graphs, pages 239–273. Academic Press, New York, NY, 1973.

Roese 1997 N. J. Roese. Counterfactual thinking. Psychological Bulletin, 121:133–148, 1997.

rojas2016 M. Rojas-Carulla, B. Schölkopf, R. Turner, and J. Peters. Causal transfer in machine learning. ArXiv e-prints (1507.05333v3), 2016.

Roos 等 2008 T. Roos, T. Silander, P. Kontkanen, and P. Myllymaki. Bayesian network structure learning using factorized nml universal models. In 2008 Information Theory and Applications Workshop, pages 272–276, 2008.

Rosenbaum 与 Rubin 1983 P. R. Rosenbaum and D. B. Rubin. The central role of the propensity score in observational studies for causal effects. Biometrika, 70(1):41–55, 1983.

Rothenhäusler 2015 D. Rothenhäusler, C. Heinze, J. Peters, and N. Meinshausen. backShift: Learning causal cyclic graphs from unknown shift interventions. In Advances in Neural Information Processing Systems 28 (NIPS), pages 1513–1521, 2015.

Rubin 1974 D. B. Rubin. Estimating causal effects of treatments in randomized and nonrandomized studies. Journal of Educational Psychology, 66:688–701, 1974.

Rubin 2004 D. B. Rubin. Direct and indirect causal effects via potential outcomes. Scandinavian Journal of Statistics, 31(2):161–170, 2004.

Rubin 2005 D. B. Rubin. Causal inference using potential outcomes. Journal of the American Statistical Association, 100(469):322–331, 2005.

Sadeghi 2014 K. Sadeghi and S. Lauritzen. Markov properties for mixed graphs. Bernoulli, 20 (2):676–696, 2014.

Schölkopf 与 Smola 2002 B. Schölkopf and A. J. Smola. Learning with Kernels. MIT Press, Cambridge, MA, 2002.

scholkopf2012 B. Schölkopf, D. Janzing, J. Peters, E. Sgouritsa, K. Zhang, and J. M. Mooij. On causal and anticausal learning. In Proceedings of the 29th International Conference on Machine Learning (ICML), pages 1255–1262, 2012.

Schölkopf 等 2015 B. Schölkopf, D. W. Hogg, D. Wang, D. Foreman-Mackey, D. Janzing, C.-J. Simon-Gabriel, and J. Peters. Removing systematic errors for exoplanet search via latent causes. In Proceedings of the 32nd International Conference on Machine Learning (ICML), pages 2218–2226, 2015.

Schölkopf 等 2016 B. Schölkopf, D. W. Hogg, D. Wang, D. Foreman-Mackey, D. Janzing, C.-J. Simon-Gabriel, and J. Peters. Modeling confounding by half-sibling regression. Proceedings of the National Academy of Sciences, 113(27):7391–7398, 2016.

Schreiber 2000 T. Schreiber. Measuring information transfer. Physical Review Letters, 85:461– 464, 2000.

Sgouritsa 2013 E. Sgouritsa, D. Janzing, J. Peters, and B. Schölkopf. Identifying finite mixtures of nonparametric product distributions and causal inference of confounders. In Proceedings of the 29th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 556–565, 2013.

Sgouritsa 等 2015 E. Sgouritsa, D. Janzing, P. Hennig, and B. Schölkopf. Inference of cause and effect with unsupervised inverse regression. In Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 847–855, 2015.

Shajarisales 等 2015 N. Shajarisales, D. Janzing, B. Schölkopf, and M. Besserve. Telling cause from effect in deterministic linear dynamical systems. In Proceedings of the 32nd International Conference on Machine Learning (ICML), pages 285–294, 2015.

Sheehan 等 2014 N. A. Sheehan, M. Bartlett, and J. Cussens. Improved maximum likelihood reconstruction of complex multi-generational pedigrees. Theoretical Population Biology, 97:11–19, 2014.

shimizu2006 S. Shimizu, P. O. Hoyer, A. Hyvärinen, and A. J. Kerminen. A linear non-Gaussian acyclic model for causal discovery. Journal of Machine Learning Research, 7: 2003–2030, 2006.

Shimizu 等 2011 S. Shimizu, T. Inazumi, Y. Sogawa, A. Hyvärinen, Y. Kawahara, T. Washio, P. O. Hoyer, and K. Bollen. DirectLiNGAM: A direct method for learning a linear non-Gaussian structural equation model. Journal of Machine Learning Research, 12:1225–1248, 2011.

Shimodaira 2000 H. Shimodaira. Improving predictive inference under covariate shift by weighting the log-likelihood function. Journal of Statistical Planning and Inference, 90 (2):227–244, 2000.

Shojaie 与 Michailidis 2010 A. Shojaie and G. Michailidis. Penalized likelihood methods for estimation of sparse high dimensional directed acyclic graphs. Biometrika, 97(3):519–538, 2010.

Shpitser 与 Pearl 2006 I. Shpitser and J. Pearl. Identification of joint interventional distributions in recursive semi-Markovian causal models. In Proceedings of the 21st AAAI Conference on Artificial Intelligence — Volume 2, pages 1219–1226, 2006.

Shpitser 与 Pearl 2008a I. Shpitser and J. Pearl. Complete identification methods for the causal hierarchy. Journal of Machine Learning Research, 9:1941–1979, 2008a.

Shpitser 2008b I. Shpitser and J. Pearl. Dormant independence. In Proceedings of the 23rd AAAI Conference on Artificial Intelligence, pages 1081–1087, 2008b.

Shpitser 等 2010 I. Shpitser, T. J. VanderWeele, and J. M. Robins. On the validity of covariate adjustment for estimating causal effects. In Proceedings of the 26th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 527–536, 2010.

Shpitser 2012 I. Shpitser, T. S. Richardson, J. M. Robins, and R. Evans. Parameter and structure learning in nested Markov models. ArXiv e-prints (1207.5058), 2012.

Shpitser 2014 I. Shpitser, R. J. Evans, T. S. Richardson, and J. M. Robins. Introduction to nested Markov models. Behaviormetrika, 41:3–39, 2014.

Silander 与 Myllymak 2006 T. Silander and P. Myllymak. A simple approach for finding the globally optimal Bayesian network structure. In Proceedings of the 22nd Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 445–452, 2006.

Silva 2014 R. Silva and R. Evans. Causal inference through a witness program. In Advances in Neural Information Processing Systems 27 (NIPS), pages 298–306, 2014.

Silva 2009 R. Silva and Z. Ghahramani. The hidden life of latent variables: Bayesian learning with mixed graph models. Journal of Machine Learning Research, 10:1187– 1238, 2009.

Silva 2006 R. Silva, R. Scheines, C. Glymour, and P. Spirtes. Learning the structure of linear latent variable models. Journal of Machine Learning Research, 7:191–246, 2006.

simon1953 H. A. Simon. Causal ordering and identifiability. In W. C. Hood and T. C. Koopmans, editors, Studies in Econometric Methods, pages 49–74. Wiley, New York, NY, 1953. Cowles Commission for Research in Economics, Monograph No. 14.

Simpson 1951 E. H. Simpson. The interpretation of interaction in contingency tables. Journal of the Royal Statistical Society, Series B: Statistical Methodology, 13:238–241, 1951.

skitovic1954 V. P. Skitovič. Linear forms in independent random variables and the normal distribution law (in Russian). Izvestiia Akademii Nauk SSSR, Serija Matematiceskie, 18:185–200, 1954.

skitovic1962 V. P. Skitovič. Linear combinations of independent random variables and the normal distribution law. Selected Translations in Mathematical Statistics and Probability, 2:211–228, 1962.

Solomonoff 1964 R. Solomonoff. A formal theory of inductive inference. Information and Control, Part II, 7(2):224–254, 1964.

Spearman 1904 C. Spearman. General intelligence, objectively determined and measured. The American Journal of Psychology, 15(2):201–292, 1904.

Spirtes 2001 P. Spirtes. An anytime algorithm for causal inference. In Proceedings of the 8th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 213–221, 2001.

Spirtes 2010 P. Spirtes. Introduction to causal inference. Journal of Machine Learning Research, 11:1643–1662, 2010.

Spirtes 等 2000 P. Spirtes, C. Glymour, and R. Scheines. Causation, Prediction, and Search. MIT Press, Cambridge, MA, 2nd edition, 2000.

Splawa-Neyman 等 1990 J. Splawa-Neyman, D. M. Dabrowska, and T. P. Speed. On the application of probability theory to agricultural experiments. Essay on principles. Section 9. Statistical Science, 5(4):465–472, 1990.

spohn1980 W. Spohn. Stochastic independence, causal independence, and shieldability. Journal of Philosophical Logic, 9:73–99, 1980.

Stanley 1973 R. P. Stanley. Acyclic orientations of graphs. Discrete Mathematics, 7(5):171–178, 1973.

Steinwart 与 Christmann 2008 I. Steinwart and A. Christmann. Support Vector Machines. Springer, New York, NY, 2008.

Steudel 2015 B. Steudel and N. Ay. Information-theoretic inference of common ancestors. Entropy, 17(4):2304–2327, 2015.

Steudel 等 2010 B. Steudel, D. Janzing, and B. Schölkopf. Causal Markov condition for submodular information measures. In Proceedings of the 23rd Annual Conference on Learning Theory (COLT), pages 464–476, 2010.

Studený 与 Haws 2014 M. Studený and D. Haws. Learning Bayesian network structure: Towards the essential graph by integer linear programming tools. International Journal of Approximate Reasoning, 55:1043–1071, 2014.

Sugiyama 与 Kawanabe 2012 M. Sugiyama and M. Kawanabe. Machine Learning in Non-Stationary Environment. MIT Press, Cambridge, MA, 2012.

Sun 等 2006 X. Sun, D. Janzing, and B. Schölkopf. Causal inference by choosing graphs with most plausible Markov kernels. In Proceedings of the 9th International Symposium on Artificial Intelligence and Mathematics, pages 1–11, 2006.

Sutton 与 Barto 2015 R. S. Sutton and A. G. Barto. Reinforcement Learning: An Introduction. MIT Press, Cambridge, MA, 2nd edition, 2015.

Teyssier 与 Koller 2005 M. Teyssier and D. Koller. Ordering-based search: A simple and effective algorithm for learning Bayesian networks. In Proceedings of the 21st Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 584–590, 2005.

Tian 2002 J. Tian. Studies in Causal Reasoning and Learning. PhD thesis, Department of Computer Science, University of California, Los Angeles, CA, 2002.

Tian 与 Pearl 2001 J. Tian and J. Pearl. Causal discovery from changes. In Proceedings of the 17th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 512– 522, 2001.

Tian 2002 J. Tian and J. Pearl. On the testable implications of causal models with hidden variables. In Proceedings of the 18th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 519–527, 2002.

Tillman 等 2009 R. Tillman, A. Gretton, and P. Spirtes. Nonlinear directed acyclic structure learning with weakly additive noise models. In Advances in Neural Information Processing Systems 22 (NIPS), pages 1847–1855, 2009.

Tillman 与 Eberhardt 2014 R. E. Tillman and F. Eberhardt. Learning causal structure from multiple datasets with similar variable sets. Behaviormetrika, 41(1):41–64, 2014.

Triantafillou 与 Tsamardinos 2015 S. Triantafillou and I. Tsamardinos. Constraint-based causal discovery from multiple interventions over overlapping variable sets. Journal of Machine Learning Research, 16:2147–2205, 2015.

Triantafillou 等 2010 S. Triantafillou, I. Tsamardinos, and I. G. Tollis. Learning causal structure from overlapping variable sets. In Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS), pages 860–867, 2010.

Tsamardinos 等 2006 I. Tsamardinos, L. E. Brown, and C. F. Aliferis. The max-min hill-climbing Bayesian network structure learning algorithm. Machine Learning, 65(1):31– 78, 2006.

Uhler 等 2013 C. Uhler, G. Raskutti, P. Bühlmann, and B. Yu. Geometry of the faithfulness assumption in causal inference. The Annals of Statistics, 41(2):436–463, 2013.

Ullman 1979 S. Ullman. The Interpretation of Visual Motion. MIT Press, Cambridge, MA, 1979.

Urner 等 2011 R. Urner, S. Shalev-Shwartz, and S. Ben-David. Access to unlabeled data can speed up prediction time. In Proceedings of the 28th International Conference on Machine Learning (ICML), pages 641–648, 2011.

van de Geer 2009 S. A. van de Geer. Empirical Processes in M-Estimation. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, Cambridge, UK, 2009.

Vapnik 1998 V. N. Vapnik. Statistical Learning Theory. Wiley, New York, NY, 1998.

Verma 与 Pearl 1988 T. Verma and J. Pearl. Causal networks: Semantics and expressiveness. In Proceedings of the 4th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 352–359, 1988.

Verma 与 Pearl 1991 T. Verma and J. Pearl. Equivalence and synthesis of causal models. In Proceedings of the 6th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 255–270, 1991.

Voiculescu 1997 D. Voiculescu, editor. Free Probability Theory, volume 12 of Fields Institute Communications. American Mathematical Society, Providence, RI, 1997.

Wald 1950 A. Wald. Statistical Decision Functions. Wiley, New York, NY, 1950.

Wang 与 Tchetgen Tchetgen 2016 L. Wang and E. Tchetgen Tchetgen. Bounded, efficient and triply robust estimation of average treatment effects using instrumental variables. ArXiv e-prints (1611.09925), 2016.

White 2010 H. White and X. Lu. Granger causality and dynamic structural systems. Journal of Financial Econometrics, 8(2):193–243, 2010.

Wiener 1956 N. Wiener. The theory of prediction. In E. Beckenbach, editor, Modern Mathematics for Engineers. McGraw-Hill, New York, NY, 1956.

Williams 1986 H. P. Williams. Fourier' s method of linear programming and its dual. The American Mathematical Monthly, 93(9):681–695, 1986.

Wishart 1928 J. Wishart. Sampling errors in the theory of two factors. British Journal of Psychology, pages 180–187, 1928.

Wood 2006 S. N. Wood. Generalized Additive Models: An Introduction with R. Chapman & Hall/CRC, London, UK, 2006.

Wright 1928 P. G. Wright. The Tariff on Animal and Vegetable Oils. Investigations in International Commercial Policies. Macmillan, New York, NY, 1928.

wright1918 S. Wright. On the nature of size factors. Genetics, 3:367–374, 1918.

wright1920 S. Wright. The relative importance of heredity and environment in determining the piebald pattern of guinea-pigs. Proceedings of the National Academy of Sciences, 6(6):320–332, 1920.

wright1921 S. Wright. Correlation and causation. Journal of Agricultural Research, 20(7): 557–585, 1921.

Wright 1934 S. Wright. The method of path coefficients. Annals of Mathematical Statistics, 5 (3):161–215, 1934.

Zadnik 等 2000 K. Zadnik, L. A. Jones, B. C. Irvin, R. N. Kleinstein, R. E. Manny, J. A. Shin, and D. O. Mutti. Vision: Myopia and ambient night-time lighting. Nature, 404: 143–144, 2000.

Zhang 2008a J. Zhang. On the completeness of orientation rules for causal discovery in the presence of latent confounders and selection bias. Artificial Intelligence, 172: 1873–1896, 2008a.

Zhang 2008b J. Zhang. Causal reasoning with ancestral graphs. Journal of Machine Learning Research, 9:1437–1474, 2008b.

Zhang 与 Spirtes 2003 J. Zhang and P. Spirtes. Strong faithfulness and uniform consistency in causal inference. In Proceedings of the 19th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 632–639, 2003.

Zhang 2005 J. Zhang and P. Spirtes. A characterization of Markov equivalence classes for ancestral graphical models. Technical Report No. CMU-PHIL-168, 2005.

Zhang 与 Spirtes 2008 J. Zhang and P. Spirtes. Detection of unfaithfulness and robust causal inference. Minds and Machines, 18(2):239–271, 2008.

Zhang 与 Chan 2006 K. Zhang and L. Chan. Extensions of ICA for causality discovery in the Hong Kong stock market. In 13th International Conference on Neural Information Processing, (ICONIP), pages 400–409, 2006.

Zhang 与 Hyvärinen 2009 K. Zhang and A. Hyvärinen. On the identifiability of the post-nonlinear causal model. In Proceedings of the 25th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 647–655, 2009.

Zhang 等 2011 K. Zhang, J. Peters, D. Janzing, and B. Schölkopf. Kernel-based conditional independence test and application in causal discovery. In Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 804– 813, 2011.

zhang2013 K. Zhang, B. Schölkopf, K. Muandet, and Z. Wang. Domain adaptation under target and conditional shift. In Proceedings of the 30th International Conference on Machine Learning (ICML), pages 819–827, 2013.

zhang2015 K. Zhang, M. Gong, and B. Schölkopf. Multi-source domain adaptation: A causal view. In Proceedings of the 29th AAAI Conference on Artificial Intelligence, pages 3150–3157, 2015.

Zscheischler 等 2011 J. Zscheischler, D. Janzing, and K. Zhang. Testing whether linear equations are causal: A free probability theory approach. In Proceedings of the 27th Annual Conference on Uncertainty in Artificial Intelligence (UAI), pages 839–846, 2011.

zurek1989 W. Zurek. Algorithmic randomness and physical entropy. Physical Review A, 40 (8):4731–4751, 1989.

原书索引

以下保留原书索引的英文排序、全部条目、子条目和原版页码；这些数字是 2017 版的印刷页码，不是本译本页码. 有链接的中文条目跳转至译本中相应主题所在的章节或小节，不能理解为对每个原页逐页对应的定位. 原书交叉指引中出现而未单列的条目不另造内容.

ACE 见平均因果效应.

加性噪声模型（additive noise model） 48、50、52、69、137、138、140、151、190、208.

调整（adjustment） 109.

ANM 见加性噪声模型.

时间之箭（arrow of time） 29、50.

自回归模型（autoregressive models） 50、199、208.

平均因果效应（average causal effect） 112、116、175、176.

后门判据（backdoor criterion） 115.

Bayesian Dirichlet 等价评分 150.

Bayesian Dirichlet 评分 149.

Bayesian 信息准则 139、149、150、178.

Bayesian 方法 149.

BD 评分 见 Bayesian Dirichlet 评分.

BDe 评分 见 Bayesian Dirichlet 等价评分.

BIC 见 Bayesian 信息准则.

CAM 见因果加性模型.

因果加性模型（causal additive model） 140.

因果发现（causal discovery） 见因果学习.

因果效应（causal effect） 见总因果效应.

因果学习（causal learning） 135.

因果 Markov 条件 105、106.

因果极小性（causal minimality） 107、108、109.

因果充分性（causal sufficiency） 见充分性.

瓶颈点（choke points） 189.

碰撞点（collider） 见图.

共同原因（common cause） 11、95、104、129、172、173、175、187、206.

条件独立（conditional independence） 214.

混杂因素（confounder） 见共同原因.

反事实（counterfactuals） 36、96、106.

DAG 见图.

DCM 见动态因果建模.

后代（descendant） 见图.

有向无环图（directed acyclic graph） 见图.

分布等价（distribution equivalence） 150.

动态因果建模（dynamic causal modeling） 210.

动态规划（dynamic programming） 151.

熵（entropy）
Shannon 熵：59、67、68、127、187.
转移熵：205、206.

相等误差方差（equal error variances） 139.

忠实性（faithfulness） 107、136.

FCI 算法 184.

fMRI 见功能磁共振成像.

功能磁共振成像（functional magnetic resonance imaging） 211.

GES 见贪心等价搜索.

GIES 见贪心干预等价搜索.

Granger 因果 201、202、203、204–206、208、211.

图（graph）
碰撞点（collider）：82.
d 分离：83.
后代（descendant）：82.
有向无环图（DAG）：82.
诱导路径图（IPG）：182.
极大祖先图（MAG）：180.
父节点（parent）：82.
部分祖先图（PAG）：180.

部分有向无环图（PDAG）：82.
部分定向诱导路径图（POIPG）：182.
路径（path）：82.
v 结构：82、102、145.
Y 结构：177、182、184.

贪心等价搜索（greedy equivalence search） 150.

贪心干预等价搜索（greedy interventional equivalence search） 153.

IC 算法 143、144.

ICA 见独立分量分析.

ILP 见整数线性规划.

独立性（independence）
因果机制：16、47、54、57、72、77.
一般视角假设（generic viewpoint assumption）：15.
噪声：18.
对象：127.
随机变量：213.
运动恢复结构（structure from motion）：16.

独立分量分析（independent component analysis） 139、152、190.

诱导路径图（induced path graph） 见图.

瞬时效应（instantaneous effects） 198.

工具变量（instrumental variable） 175、186.

整数线性规划（integer linear programming） 151.

干预充分性（interventional sufficiency） 见充分性.

干预（interventions） 34、88.

不变性（invariance） Simon 判据：24.

不变的（invariant）
因果预测：154.
条件分布：113.
机制：20.

逆概率加权（inverse probability weighting） 159、160.

IPG 见图.

Kolmogorov 复杂度 47、59、60、128.

潜投影（latent projection） 179、182.

线性非高斯无环模型（linear non-Gaussian acyclic model） 48–50、139、140、208.

LiNGAM 见线性非高斯无环模型.

MAG 见图.

边缘化（marginalization） 174、179.

Markov 条件 109.

Markov 等价 102.

Markov 性质 100、101、104、105、108.

极大祖先图（maximal ancestral graph） 见图.

机制（mechanism） 9、17.
独立的：19、20.
不变的：18、20.

噪声（noises） 独立的：8.

非后代（non-descendant） 见图.

非确定性多项式时间（nondeterministic polynomial time） 145、150、151.

NP 见非确定性多项式时间.

PAG 见图.

父节点（parent） 见图.

部分祖先图（partially ancestral graph） 见图.

部分有向无环图（partially directed acyclic graph） 见图.

部分定向诱导路径图（partially oriented induced path graph） 见图.

路径（path） 见图.

路径模型（path model） 22.

PC 算法 143、145、179、184.

PDAG 见图.

POIPG 见图.

潜在结果（potential outcomes） 122.

倾向得分匹配（propensity score matching） 117.

随机变量（random variable） 213.

回归（regression） 215.
半同胞回归：157.

回归后独立性检验（regression with subsequent independence test） 152.

RESIT 见回归后独立性检验.

SCM 见结构因果模型.

选择偏差（selection bias） 104.

SEM 见结构方程模型.

半监督学习（semi-supervised learning） 71.

SGS 算法 143、144.

SIC 见谱独立判据.

Simpson 悖论 172、174、196.

谱独立判据（spectral independence criterion） 208、209.

结构因果模型（structural causal model） 9、22、33、83.

结构方程模型（structural equation model） 见结构因果模型.

结构学习（structure learning） 见因果学习.

充分性（sufficiency）
因果充分性：171、173.
干预充分性：171、172、173.

四分差约束（tetrad constraints） 189.

时间序列（time series）
全时间图：198.
汇总图：199、200.

总因果效应（total causal effect） 91.

转移熵（transfer entropy） 见熵.

v **结构** 见图.

变量（variable）
内生：23.
外生：23.

视觉感知（visual perception） 15、30.

Y 结构 见图.

原书丛书书目

自适应计算与机器学习（Adaptive Computation and Machine Learning）

主编：Francis Bach.

副主编：Christopher Bishop、David Heckerman、Michael Jordan、Michael Kearns.

以下为冻结源书末所列书目；保留原书名与作者，中文仅为本译稿中的题名译释，不声称为官方译名.

生物信息学：机器学习方法 *Bioinformatics: The Machine Learning Approach*, Pierre Baldi、Søren Brunak.

强化学习导论 *Reinforcement Learning: An Introduction*, Richard S. Sutton、Andrew G. Barto.

机器学习与数字通信中的图模型 *Graphical Models for Machine Learning and Digital Communication*, Brendan J. Frey.

图模型中的学习 *Learning in Graphical Models*, Michael I. Jordan.

因果、预测与搜索，第 2 版 *Causation, Prediction, and Search*, Peter Spirtes、Clark Glymour、Richard Scheines.

数据挖掘原理 *Principles of Data Mining*, David Hand、Heikki Mannila、Padhraic Smyth.

生物信息学：机器学习方法，第 2 版 *Bioinformatics: The Machine Learning Approach*, Pierre Baldi、Søren Brunak.

学习核分类器：理论与算法 *Learning Kernel Classifiers: Theory and Algorithms*, Ralf Herbrich.

核学习：支持向量机、正则化、优化及其他 *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*, Bernhard Schölkopf、Alexander J. Smola.

机器学习导论 *Introduction to Machine Learning*, Ethem Alpaydin.

机器学习中的高斯过程 *Gaussian Processes for Machine Learning*, Carl Edward Rasmussen、Christopher K.I. Williams.

半监督学习 *Semi-Supervised Learning*, Olivier Chapelle、Bernhard Schölkopf、Alexander Zien 主编.

最小描述长度原理 *The Minimum Description Length Principle*, Peter D. Grünwald.

统计关系学习导论 *Introduction to Statistical Relational Learning*, Lise Getoor、Ben Taskar 主编.

概率图模型：原理与技术 *Probabilistic Graphical Models: Principles and Techniques*, Daphne Koller、Nir Friedman.

机器学习导论，第 2 版 *Introduction to Machine Learning*, Ethem Alpaydin.

非平稳环境中的机器学习：协变量偏移适应导论 *Machine Learning in Non-Stationary Environments: Introduction to Covariate Shift Adaptation*, Masashi Sugiyama、Motoaki Kawanabe.

提升方法：基础与算法 *Boosting: Foundations and Algorithms*, Robert E. Schapire、Yoav Freund.

机器学习：概率视角 *Machine Learning: A Probabilistic Perspective*, Kevin P. Murphy.

机器学习基础 *Foundations of Machine Learning*, Mehryar Mohri、Afshin Rostami、Ameet Talwalker.

机器学习导论，第 3 版 *Introduction to Machine Learning*, Ethem Alpaydin.

深度学习 *Deep Learning*, Ian Goodfellow、Yoshua Bengio、Aaron Courville.

因果推断要素：基础与学习算法 *Elements of Causal Inference: Foundations and Learning Algorithms*, Jonas Peters、Dominik Janzing、Bernhard Schölkopf.

术语索引

中文术语	英文术语	页码
干预	intervention	5
结构因果模型	structural causal model，SCM	6
独立因果机制	independent causal mechanisms，ICM	11
反事实	counterfactual	23
加性噪声模型	additive noise model，ANM	31
d 分离	d-separation	57
Markov 等价性	Markov equivalence	70
因果 Markov 条件	causal Markov condition	72
忠实性	faithfulness	73
因果极小性	causal minimality	73
协变量调整	covariate adjustment	75
极大祖先图	maximal ancestral graph，MAG	121
部分祖先图	partially ancestral graph，PAG	121
诱导路径图	induced path graph，IPG	122
潜投影	latent projection	122
无环有向混合图	acyclic directed mixed graph，ADMG	122
嵌套 Markov 性质	nested Markov property	122
无弓	bow-free	123
链图	chain graph	123
瞬时效应	instantaneous effects	134
全时间图	full time graph	134
汇总图	summary graph	134
向量自回归模型	vector autoregressive model，VAR	136
转移熵	transfer entropy	139
谱独立判据	spectral independence criterion，SIC	142
动态因果建模	dynamic causal modeling，DCM	143