

几何深度学习

网格、群、图、测地线与规范

2021 年 proto-book 工作译稿

Michael M. Bronstein, Joan Bruna, Taco Cohen, Petar Veličković

arXiv:2104.13478v2 · 2021
Model: gpt-6.1-terra；gpt-6.1-sol（末文恢复与审校修订）
审核：曹溪能
Updated: 2026-11-05

译本说明

原稿扉页信息（源 PDF 第 1 页）：

Geometric Deep Learning
Grids, Groups, Graphs, Geodesics, and Gauges

Michael M. Bronstein[1], Joan Bruna[2], Taco Cohen[3], Petar Veličković[4]
2021 年 5 月 4 日

1. Imperial College London / USI IDSIA / Twitter。

2. New York University。

3. Qualcomm AI Research。Qualcomm AI Research 是 Qualcomm Technologies, Inc. 的一项计划。

4. DeepMind。

原稿页边版本标记为 arXiv:2104.13478v2 [cs.LG]，2021 年 5 月 2 日；扉页所列文稿日期为 2021 年 5 月 4 日，二者按原文分别保留。

译者说明：只覆盖冻结的 2021 年 160 页 proto-book（`01_2104.pdf`），不换后续教材。原稿扉页、目录、前言、符号表、七章正文、致谢及 340 条书目已有对应初稿；目录按译稿页码重排，书目保留原语种。本候选正在依独立审校修订，并补入引文内部跳转与源码包重建证据；最终验收以随附清单为准，未发布。已核模型为 gpt-6.1-terra/high 及末文恢复与审校修订的 gpt-6.1-sol/high；更早未知者不追认。审核署名是版式字段，不代表本人审阅。研究及企业状态保留 2021 年语境。附录“原文疑点与适用条件提示”为明确标注的译者审校材料，不属于原书；其中按源页定位符号和适用条件，正文未静默修改源公式。

审核：曹溪能

目录

译本说明 **i**

前言 **v**

符号表 **vii**

第一章 引言 **1**

第二章 高维空间中的学习 **3**

2.1 通过函数正则性引入归纳偏置 3

2.2 维数灾难 5

第三章 几何先验 **9**

3.1 对称性、表示与不变性 10

3.2 同构与自同构 15

3.3 形变稳定性 17

3.4 尺度分离 20

3.5 几何深度学习蓝图 24

第四章 几何定义域：五个 G **29**

4.1 图与集合 29

4.2 网格与欧几里得空间 34

4.3 群与齐性空间 38

4.4 测地线与流形 42

4.5 规范与丛 55
4.6 几何图与网格 59

第五章 几何深度学习模型 69
5.1 卷积神经网络 70
5.2 群等变 CNN 75
5.3 图神经网络 78
5.4 Deep Sets、Transformer 与潜在图推断 81
5.5 等变消息传递网络 83
5.6 内禀网格 CNN 85
5.7 循环神经网络 89
5.8 长短期记忆网络 94

第六章 问题与应用 103

第七章 历史视角 117

致谢 129

附录 A 原文疑点与适用条件提示 131

参考文献 137

前言

自欧几里得的《几何原本》问世以来，将近两千年间，几何一词一直是欧几里得几何的同义词，因为当时并不存在其他种类的几何。到了十九世纪，罗巴切夫斯基、鲍耶、高斯和黎曼构造出了非欧几何的例子，欧几里得的独占地位才告终结。至该世纪末，这些研究已分化为不同领域，数学家和哲学家争论着各种几何的有效性、彼此之间的关系，以及“唯一真正的几何”的性质。

年轻的数学家费利克斯 · 克莱因指出了一条走出困境的道路。1872 年，他被任命为巴伐利亚小城埃尔朗根大学的教授。在一份后来以“埃尔朗根纲领”之名载入数学史的研究计划书中，克莱因提出，将几何视为对不变量的研究：这些性质在某一类变换下保持不变，而这类变换称为该几何的对称性。[1]这一方法表明，通过恰当选择对称变换，并用群论语言将其形式化，就可以定义当时已知的各种几何，从而使问题变得清晰。例如，欧几里得几何关注长度和角度，因为欧几里得变换群（旋转和平移）保持这些性质；仿射几何则研究仿射变换群保持的平行性。考察相应的群，这些几何之间的关系便一目了然：欧几里得群是仿射群的子群，而仿射群又是射影变换群的子群。

埃尔朗根纲领对几何的影响极其深远。此外，其影响还扩展到其他领域，尤其是物理学：对称性原理使人们能够从对称性的第一性原理推导守恒定律（这一惊人结果称为诺特定理），甚至使人们能够将基本粒子分类为对称

[1]一种流行说法认为，埃尔朗根纲领是在克莱因 1872 年 10 月的就职演讲中提出的。克莱因确实作过一次演讲（但日期是同年 12 月 7 日），不过听众并非数学家，内容主要涉及他的数学教育理念。如今所谓的“埃尔朗根纲领”，实际上是他为受聘教授准备的研究计划小册子 *Vergleichende Betrachtungen über neuere geometrische Forschungen*（“关于近期几何研究的比较考察”）。参见 Tobies（2019）。


Vergleichende Betrachtungen
über
neuere geometrische Forschungen
von
Dr. Felix Klein,
Program
Erlangen,

1872 年埃尔朗根纲领研究计划小册子的封面（源 PDF 第 5 页）。

群的不可约表示。如今在纯数学中广泛应用的范畴论，用其创立者 Samuel Eilenber 和 Saunders Mac Lane 的话说，可以“看作克莱因埃尔朗根纲领的延续，因为带有变换群的几何空间被推广为带有映射代数的范畴”。[2]

在写作本文时，深度学习领域的状况与十九世纪的几何颇有几分相似。针对各种数据的神经网络架构层出不穷，统一原理却寥寥无几。正如过去那样，这使得理解各种方法之间的关系变得困难，也不可避免地导致相同概念在不同应用领域被反复发明、重新命名。对于初学者而言，消化数量庞大而又彼此重复的思想无疑是一场噩梦。

本文尝试将埃尔朗根纲领的思路应用于深度学习，最终目标是使这一领域系统化并“将各个点联系起来”。我们将这一几何化尝试称为“几何深度学习”，并秉承费利克斯 · 克莱因的精神，提出从对称性和不变性的第一性原理出发，推导不同的归纳偏置及实现这些偏置的网络架构。我们尤其关注一大类用于分析无结构集合、网格、图和流形的神经网络，并表明可以统一地将它们理解为尊重这些定义域的结构和对称性的方法。

我们相信，本文会吸引广泛的深度学习研究者、实践者和爱好者。初学者可以将其作为几何深度学习的概览和入门材料；经验丰富的深度学习专家或许能发现从基本原理推导熟悉架构的新方法，以及一些令人惊讶的联系；实践者则可能对如何解决各自领域的问题获得新的见解。

现代机器学习发展如此迅速，撰写这类文本的风险在于，它可能尚未问世就已过时、失去意义。由于我们着眼于基础，希望所讨论的关键概念能够超越其具体实现——或者，用克洛德 · 阿德里安 · 爱尔维修的话说：“掌握某些原理，便很容易弥补对某些事实的无知。”（Helvétius，1759）

[2]参见 Marquis（2009）。

符号表

Ω, u	定义域、定义域上的点
$x(u) \in \mathcal{X}(\Omega, \mathcal{C})$	定义域上的信号，形式为 $x : \Omega \to \mathcal{C}$
$f(x) \in \mathcal{F}(\mathcal{X}(\Omega))$	定义域上信号的函数，形式为 $f : \mathcal{X}(\Omega) \to \mathcal{Y}$
$\mathfrak{G}, \mathfrak{g}$	群、群元素
$\mathfrak{g}.u, \rho(\mathfrak{g})$	群作用、群表示
$\mathbf{X} \in \mathcal{C}^{\lvert\Omega\rvert \times s}$	表示离散定义域上信号的矩阵
$\mathbf{x}_u \in \mathcal{C}^s$	表示离散定义域信号 $\mathbf{X}$ 在元素 $u \in \Omega$ 上取值的向量
$x_{uj} \in \mathcal{C}$	表示离散定义域信号 $\mathbf{X}$ 在元素 $u \in \Omega$ 上第 j 个分量的标量
$\mathbf{F}(\mathbf{X})$	离散定义域信号上的函数，以矩阵形式返回另一个离散定义域信号
$\tau : \Omega \to \Omega$	定义域的自同构
$\eta : \Omega \to \Omega'$	两个不同定义域之间的同构
$\sigma : \mathcal{C} \to \mathcal{C}'$	激活函数（逐点非线性）
$G = (\mathcal{V}, \mathcal{E})$	节点为 $\mathcal{V}$、边为 $\mathcal{E}$ 的图
$\mathcal{T} = (\mathcal{V}, \mathcal{E}, \mathcal{F})$	节点为 $\mathcal{V}$、边为 $\mathcal{E}$、面为 $\mathcal{F}$ 的网格
$x \star \theta$	与滤波器 θ 的卷积
S_v	平移算子
φ_i	基函数
$T_u\Omega, T\Omega$	u 处的切空间、切丛
$X \in T_u\Omega$	切向量
$g_u(X, Y) = \langle X, Y \rangle_u$	黎曼度量
$\ell(\gamma), \ell_{uv}$	曲线 γ 的长度、边 (u, v) 上的离散度量

第一章　引言

过去十年见证了数据科学和机器学习的一场实验革命，深度学习方法便是其典型代表。许多先前被认为遥不可及的高维学习任务——例如计算机视觉、围棋和蛋白质折叠——实际上在适当的计算规模下都是可行的。值得注意的是，深度学习的核心建立在两个简单的算法原理之上：一是表示学习或特征学习，通过适应任务的、往往具有层次结构的特征来捕捉每项任务相应的正则性；二是通过局部梯度下降进行学习，通常以反向传播实现。

虽然在高维空间中学习一般函数是一个受维数灾难困扰的估计问题，但大多数我们感兴趣的任务并不是一般的，它们具有先验给定的重要正则性，源于物理世界内在的低维性和结构。本文旨在通过统一的几何原理揭示这些正则性；这些原理可应用于广泛的任务。

利用大型系统已知的对称性，是应对维数灾难的一种强有力的经典方法，也是大多数物理理论的基础。深度学习系统亦不例外：从早期开始，研究者就调整神经网络，利用物理测量中出现的低维几何，例如图像中的网格、时间序列中的序列、分子中的位置和动量，以及与之相应的对称性，例如平移或旋转。在下文中，我们将把这些模型和许多其他模型描述为同一底层几何正则性原理的自然实例。

这种秉承埃尔朗根纲领精神的“几何统一”工作有双重目的：一方面，它为研究最成功的神经网络架构，如卷积神经网络、循环神经网络、图神经网络和 Transformer，提供共同的数学框架；另一方面，它给出一个构造性过程，将先验物理知识纳入神经网络架构，并为构建尚待发明的未来架构提供有原理可循的方法。

在继续之前，有必要说明，我们关注的是表示学习架构及其中对数据对称性的利用。这类表示可以用于许多令人振奋的流程（例如自监督学习、生

成建模或强化学习），但这些流程并非我们的中心。因此，我们不会深入综述变分自编码器（Kingma and Welling，2013）、生成对抗网络（Goodfellow et al.，2014）、归一化流（Rezende and Mohamed，2015）、深度 Q 网络（Mnih et al.，2015）、近端策略优化（Schulman et al.，2017）或深度互信息最大化（Hjelm et al.，2019）等有影响力的神经网络流程。[1]尽管如此，我们相信，本文关注的原理在所有这些领域都有重要意义。

此外，虽然我们试图覆盖相当广泛的内容，以展示几何蓝图的力量，但本文并不试图准确概述几何深度学习现有的全部丰富研究成果。我们会深入研究几个著名架构，以展示这些原理，并将其建立在现有研究的基础上；我们希望所提供的参考文献足够充分，使读者能够切实地将这些原理应用于未来遇到或自行设计的任何几何深度架构。

[1]用于优化或正则化我们所讨论架构的技术也同样如此，例如 Adam（Kingma and Ba，2014）、dropout（Srivastava et al.，2014）或批归一化（Ioffe and Szegedy，2015）。

第二章　高维空间中的学习

在最简单的形式化表述中，监督学习考虑观测集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$。它们独立同分布地取自定义在 $\mathcal{X} \times \mathcal{Y}$ 上的基础数据分布 P，其中 $\mathcal{X}$ 和 $\mathcal{Y}$ 分别为数据和标签的定义域。这一设定的显著特点是 $\mathcal{X}$ 为高维空间：通常假定 $\mathcal{X} = \mathbb{R}^d$，即维数 d 很大的欧几里得空间。

进一步假设标签 y 由未知函数 f 生成，使得 $y_i = f(x_i)$，那么学习问题便归结为使用参数化函数类 $\mathcal{F} = \{f_{\theta \in \Theta}\}$ 来估计函数 f。神经网络是此类参数化函数类的一种常见实现，此时 $\theta \in \Theta$ 对应于网络权重。在这一理想化设定下，标签中没有噪声；现代深度学习系统通常工作在所谓的插值区间，即估计函数 $\tilde{f} \in \mathcal{F}$ 对所有 $i = 1, \ldots, N$ 均满足 $\tilde{f}(x_i) = f(x_i)$。学习算法的性能通过使用某个损失函数 $L(\cdot, \cdot)$，在从 P 抽取的新样本上的期望表现来衡量：[1]

$$R(\tilde{f}) := \mathbb{E}_P L(\tilde{f}(x), f(x)),$$

其中平方损失 $L(y, y') = \frac{1}{2}|y - y'|^2$ 是最常用的损失之一。

因此，一个成功的学习方案需要编码适合 f 的正则性概念或归纳偏置，而这通过构造函数类 $\mathcal{F}$ 和使用正则化来施加。下一节将简要介绍这一概念。

2.1　通过函数正则性引入归纳偏置

现代机器学习使用大规模、高质量的数据集；这些数据集连同适当的计算资源，促使人们设计足够丰富的函数类 $\mathcal{F}$，使之具有插值如此大量数据的

[1] 统计学习理论研究基于集中不等式的更精细的泛化概念；我们将在未来的工作中讨论其中一些概念。

能力。这种思路与神经网络十分契合，因为即便最简单的架构选择也能产生稠密的函数类。[2]逼近几乎任意函数的能力是各种普适逼近定理的主题；应用数学家和计算机科学家在 20 世纪 90 年代证明并推广了若干此类结果（例如 Cybenko（1989）、Hornik（1991）、Barron（1993）、Leshno et al.（1993）、Maiorov（1999）、Pinkus（1999））。

然而，普适逼近并不意味着不存在归纳偏置。给定具有普适逼近能力的假设空间 $\mathcal{F}$，我们可以定义复杂度度量 $c : \mathcal{F} \to \mathbb{R}_+$，并将插值问题重新定义为

$$\tilde{f} \in \arg\min_{g \in \mathcal{F}} c(g) \quad \text{满足} \quad g(x_i) = f(x_i) \quad \text{对} i = 1, \ldots, N,$$

即在假设类中寻找最正则的函数。对于标准函数空间，可以将这一复杂度度量定义为范数，使 $\mathcal{F}$ 成为巴拿赫空间，从而利用泛函分析中的大量理论结果。[3]在低维情形中，样条是函数逼近的重要工具。它们可以按上述方式表述，其中范数刻画经典的光滑性概念；例如，对三次样条可使用二阶导数的平方范数 $\int_{-\infty}^{+\infty} |f''(x)|^2 \, dx$。

对于神经网络，复杂度度量 c 可以用网络权重表示，即 $c(f_\theta) = c(\theta)$。网络权重的 L_2 范数（称为权重衰减），或所谓的路径范数（Neyshabur et al., 2015），都是深度学习文献中的常见选择。从贝叶斯观点看，这类复杂度度量也可解释为目标函数先验的负对数。更一般地，可以通过将复杂度并入经验损失而显式施加它（得到所谓的结构风险最小化），也可以通过某种优化方案隐式施加它。例如，众所周知，对欠定最小二乘目标进行梯度下降会选择 L_2 范数最小的插值解。如何将这类隐式正则化结果推广到现代神经网络，是当前研究的主题（例如 Blanc et al.（2020）、Shamir and Vardi（2020）、Razin and Cohen（2020）、Gunasekar et al.（2017））。总之，一个自然的问题随之产生：如何定义有效的先验，以捕捉现实世界预测任务中预期的正则性和复杂度？

---

[2]若集合 $A \subset \mathcal{X}$ 的闭包满足 $A \cup \{\lim_{i\to\infty} a_i : a_i \in A\} = \mathcal{X}$，则称 A 在 $\mathcal{X}$ 中稠密。这意味着 $\mathcal{X}$ 中任一点都任意接近 A 中的某个点。一个典型的普适逼近结果表明，例如，两层感知机表示的函数类 $f(x) = c^\top \operatorname{sign}(Ax + b)$ 在 $\mathbb{R}^d$ 上的连续函数空间中稠密。

[3]非正式地说，范数 $\|x\|$ 可视作向量 x 的“长度”。巴拿赫空间是赋有范数的完备向量空间。

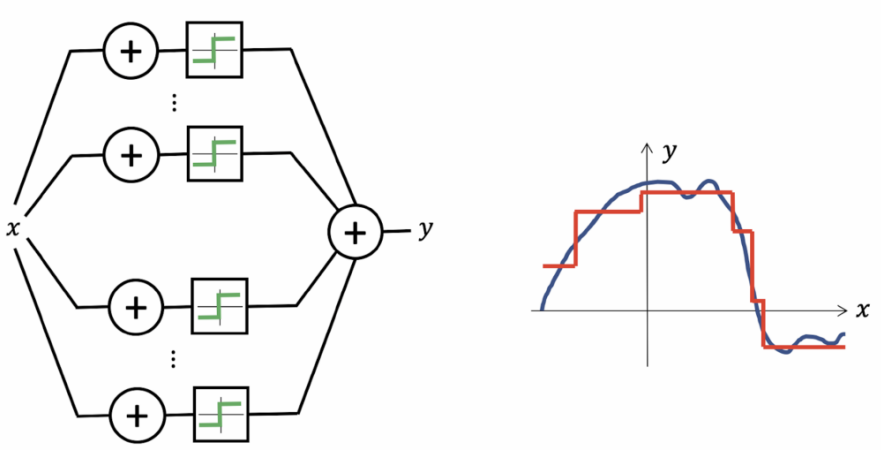


图 1: 多层感知机（Rosenblatt，1958）是最简单的前馈神经网络，也是普适逼近器：只需一个隐藏层，它们就能表示阶跃函数的组合，从而以任意精度逼近任意连续函数。

2.2 维数灾难

低维空间（$d = 1, 2$ 或 3）中的插值是一项经典信号处理任务，借助日益精细的正则性类（如样条插值、小波、曲波或脊波），可以对估计误差进行非常精确的数学控制；高维问题的情形却截然不同。

为说明其核心思想，我们考虑一个容易推广到高维的经典正则性概念：1-Lipschitz 函数 $f : \mathcal{X} \to \mathbb{R}$，即对所有 $x, x' \in \mathcal{X}$ 满足 $|f(x)-f(x')| \le \|x-x'\|$ 的函数。这一假设只要求目标函数局部光滑：如果对输入 x 作微小扰动（由范数 $\|x - x'\|$ 衡量），输出 $f(x)$ 就不能变化太大。如果我们关于目标函数 f 唯一知道的是它为 1-Lipschitz，那么预计需要多少个观测才能保证估计 $\tilde{f}$ 接近 f？图 2 表明，一般而言答案必然随维数 d 指数增长，这意味着 Lipschitz 类随着输入维数增加而增长得“太快”：在许多应用中，即使 d 不大，所需样本数也会超过宇宙中的原子数。若用全局光滑性假设，例如 Sobolev 类 $H^s(\Omega_d)$，取代 Lipschitz 类，情形也不会更好。[4]事实上，经典结

[4]若 $f \in L^2(\Omega_d)$ 且其广义 s 阶导数平方可积，则 f 属于 Sobolev 类 $H^s(\Omega_d)$：$\int |\omega|^{2s+1} |\hat{f}(\omega)|^2 \, d\omega < \infty$，其中 $\hat{f}$ 是 f 的傅里叶变换；参见第 4.2 节。

果（Tsybakov，2008）给出 Sobolev 类逼近和学习的极小极大速率，其量级为 $\epsilon^{-d/s}$；这表明，仅当 $s \propto d$ 时，对 f 附加的光滑性假设才会改善统计情况，而这一假设在实践中并不现实。

全连接神经网络定义的函数空间，通过考虑其权重上的复杂度函数 c，允许采用更灵活的正则性概念。特别地，选择促进稀疏性的正则化时，它们能够打破这种维数灾难（Bach，2017）。但代价是必须对目标函数 f 的性质作出强假设，例如假定 f 依赖于输入的一组低维投影（见图 3）。在大多数实际应用（如计算机视觉、语音分析、物理学或化学）中，感兴趣的函数往往表现出无法用低维投影表达的复杂长程关联（图 3），使这一假设并不现实。因此，有必要通过利用物理定义域的空间结构和 f 的几何先验，定义另一种正则性来源；我们将在第 3 章中讨论。

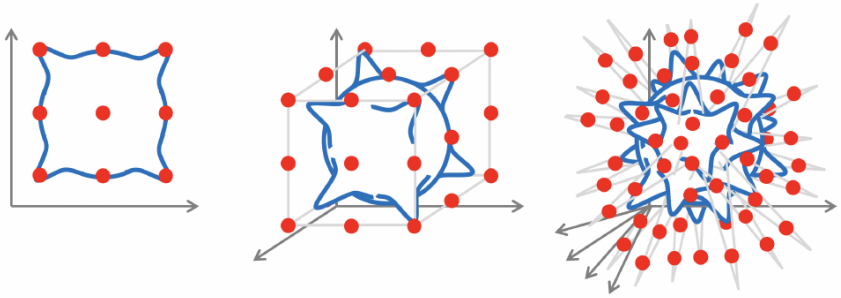


图 2: 考虑 Lipschitz 函数 $f(x) = \sum_{j=1}^{2^d} z_j \phi(x - x_j)$，其中 $z_j = \pm 1$，每个象限放置一个 $x_j \in \mathbb{R}^d$，ϕ 是局域支撑的 Lipschitz “隆起” 函数。除非在 2^d 个象限中的大多数都观测到该函数，否则预测会产生常数量级的误差。这个简单的几何论证可通过最大差异（Maximum Discrepancy；von Luxburg and Bousquet，2004）的概念形式化：对 Lipschitz 类，定义 $\kappa(d) = \mathbb{E}_{x,x'} \sup_{f \in \mathrm{Lip}(1)} \left| \frac{1}{N} \sum_l f(x_l) - \frac{1}{N} \sum_l f(x'_l) \right| \simeq N^{-1/d}$，它衡量两个独立的 N 样本平均值之间最大的期望差异。保证 $\kappa(d) \simeq \epsilon$ 需要 $N = \Theta(\epsilon^{-d})$；相应样本 $\{x_l\}_l$ 定义了该定义域的一个 ϵ-网。对于直径为 1 的 d 维欧几里得定义域，其大小按 ϵ^{-d} 指数增长。

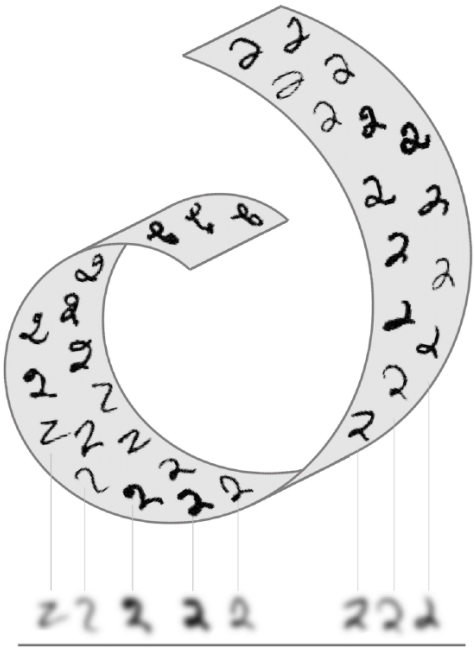


图 3: 若假定未知函数 f 可由 $f(x) \approx g(Ax)$ 很好地逼近，其中未知矩阵 $A \in \mathbb{R}^{k \times d}$ 且 $k \ll d$，那么浅层神经网络可以捕捉这种归纳偏置，参见例如 Bach（2017）。在典型应用中，对低维投影的这种依赖并不现实，图中例子对此作了说明：低通滤波器将输入图像投影到低维子空间；尽管它传达了大部分语义，仍有大量信息丢失。

第三章　几何先验

现代数据分析几乎是高维学习的代名词。第 2.1 节的简单论证揭示了维数灾难导致的从一般高维数据中学习的不可能性，但对于具有物理结构的数据，我们仍有希望，因为可以利用两条基本原理：对称性和尺度分离。在本文考虑的情形中，这种额外结构通常来自输入信号底层定义域的结构：我们假定机器学习系统处理某个定义域 Ω 上的信号（函数）。尽管在许多情况下，Ω 上各点的线性组合没有良好定义，我们仍可以对其上的信号作线性组合，即信号空间构成向量空间。[1]此外，由于可以定义信号之间的内积，这个空间是希尔伯特空间。

定义在 Ω 上、取值于 $\mathcal{C}$ 的信号所构成的空间（其中 Ω 是一个可能带有额外结构的集合，$\mathcal{C}$ 是一个向量空间，其维度称为通道）为

$$\mathcal{X}(\Omega, \mathcal{C}) = \{x : \Omega \to \mathcal{C}\}. \tag{1}$$

这是一个具有向量空间结构的函数空间。[2]信号的加法和标量乘法定义为

$$(\alpha x + \beta y)(u) = \alpha x(u) + \beta y(u) \qquad \text{对所有} u \in \Omega,$$

其中 α, β 为实标量。给定 $\mathcal{C}$ 上的内积 $\langle v, w\rangle_{\mathcal{C}}$ 和 Ω 上的测度 μ（据此可以定义积分），我们可将 $\mathcal{X}(\Omega, \mathcal{C})$ 上的内积定义为[3]

$$\langle x, y\rangle = \int_{\Omega} \langle x(u), y(u)\rangle_{\mathcal{C}}\, d\mu(u). \tag{2}$$

[1]表达式 $\alpha u + \beta v$ 要有意义，Ω 必须是向量空间。

[2]当 Ω 具有某种额外结构时，我们还可以限制 $\mathcal{X}(\Omega, \mathcal{C})$ 中信号的种类。例如，当 Ω 是光滑流形时，可以要求信号光滑。在不致混淆的情况下，我们将省略值域 $\mathcal{C}$ 以简化记号。

[3]当定义域 Ω 是离散的，可以将 μ 选为计数测度，此时积分变为求和。下文中，我们将省略测度并用 du 简写。

作为一个典型例子，取 $\Omega = \mathbb{Z}_n \times \mathbb{Z}_n$ 为二维 $n \times n$ 网格，x 为 RGB 图像（即信号 $x : \Omega \to \mathbb{R}^3$），$f$ 为作用于 $3n^2$ 维输入的函数（例如单层感知机）。正如下文将更详细展示的，定义域 Ω 通常带有某种几何结构和对称性。尺度分离源于我们能够在将信号转移到定义域的较粗版本时保留其重要特征（在本例中，即通过粗化底层网格来对图像进行下采样）。

我们将表明，这两条原理——我们将其统称为几何先验——在大多数现代深度学习架构中都十分重要。对于上述图像，几何先验以共享权重的卷积滤波器（利用平移对称性）和池化（利用尺度分离）的形式内建于卷积神经网络（CNN）中。将这些思想扩展到图和流形等其他定义域，并展示几何先验如何从基本原理中产生，是几何深度学习的主要目标，也是贯穿本文的主题。

3.1 对称性、表示与不变性

非正式地说，一个对象或系统的对称性是使该对象或系统的某种性质保持不变的变换。这类变换可以是光滑的、连续的或离散的。对称性在许多机器学习任务中无处不在。例如，在计算机视觉中，物体类别不随平移而改变，因此平移是视觉物体分类问题中的对称性。在计算化学中，预测分子性质而不依赖其空间朝向的任务要求旋转不变性。描述没有标准顺序、因而可以任意置换的粒子系统时，离散对称性自然出现；在许多动力系统中，时间反演对称性也给出离散对称性，例如满足细致平衡的系统或牛顿第二运动定律。如第 4.1 节所示，置换对称性也是分析图结构数据的核心。

对称群 一个对象的对称性集合满足若干性质。首先，可以组合对称性得到新的对称性：若 $\mathfrak{g}$ 和 $\mathfrak{h}$ 是两个对称性，则它们的复合 $\mathfrak{g} \circ \mathfrak{h}$ 和 $\mathfrak{h} \circ \mathfrak{g}$ 也是对称性。这是因为，如果两个变换都使对象保持不变，那么它们的复合也是如此。此外，对称变换总是可逆的，其逆变换也是对称性。这说明，所有对称性组成称为群的代数对象。由于群将是几何深度学习数学模型的核心，值得给出形式定义并详细讨论。[4]

[4]我们遵循群论中并置的记号约定 $\mathfrak{g} \circ \mathfrak{h} = \mathfrak{g}\mathfrak{h}$，从右向左读：先作用 $\mathfrak{h}$，再作用 $\mathfrak{g}$。顺序很重要，因为对称变换在许多情况下不可交换。熟悉李群的读者可能不习惯我们用花体字母表

群是一个集合 $\mathfrak{G}$ 连同一个称为复合的二元运算 $\circ : \mathfrak{G} \times \mathfrak{G} \to \mathfrak{G}$（为简洁起见用并置表示 $\mathfrak{g} \circ \mathfrak{h} = \mathfrak{g}\mathfrak{h}$），满足下列公理：

结合律 对所有 $\mathfrak{g}, \mathfrak{h}, \mathfrak{k} \in \mathfrak{G}$，$(\mathfrak{g}\mathfrak{h})\mathfrak{k} = \mathfrak{g}(\mathfrak{h}\mathfrak{k})$。

单位元 存在唯一的 $\mathfrak{e} \in \mathfrak{G}$，对所有 $\mathfrak{g} \in \mathfrak{G}$ 满足 $\mathfrak{e}\mathfrak{g} = \mathfrak{g}\mathfrak{e} = \mathfrak{g}$。

逆元 对每个 $\mathfrak{g} \in \mathfrak{G}$，存在唯一的逆元 $\mathfrak{g}^{-1} \in \mathfrak{G}$，使 $\mathfrak{g}\mathfrak{g}^{-1} = \mathfrak{g}^{-1}\mathfrak{g} = \mathfrak{e}$。

封闭性 群在复合下封闭：对每个 $\mathfrak{g}, \mathfrak{h} \in \mathfrak{G}$，有 $\mathfrak{g}\mathfrak{h} \in \mathfrak{G}$。

注意，交换律不是定义的一部分，即可以有 $\mathfrak{g}\mathfrak{h} \neq \mathfrak{h}\mathfrak{g}$。若对所有 $\mathfrak{g}, \mathfrak{h} \in \mathfrak{G}$ 均有 $\mathfrak{g}\mathfrak{h} = \mathfrak{h}\mathfrak{g}$，则称该群为交换群或阿贝尔群。[5]尽管有些群可能很大甚至是无限的，它们往往由少数几个称为群生成元的元素复合而成。形式上，若 $\mathfrak{G}$ 的每个元素都可写成子集 $S \subseteq \mathfrak{G}$（称为群生成元）中元素及其逆元的有限次复合，则称 $\mathfrak{G}$ 由 S 生成。例如，正三角形的对称群（二面体群 D_3）由一个 60° 旋转和一个反射生成（图 4）。我们将在下文详细讨论的一维平移群由无穷小位移生成；这是可微对称性的李群的一个例子。[6]

这里我们把群定义为抽象对象，只说明群元素如何复合，而不说明它们是什么（例如某个定义域的变换）。因此，种类很不相同的对象可能具有相同的对称群。例如，上述三角形的旋转和反射对称群与三个元素的序列的置换群相同：我们可以通过旋转和反射，以任意方式置换三角形的顶点（见图 4）。[7]

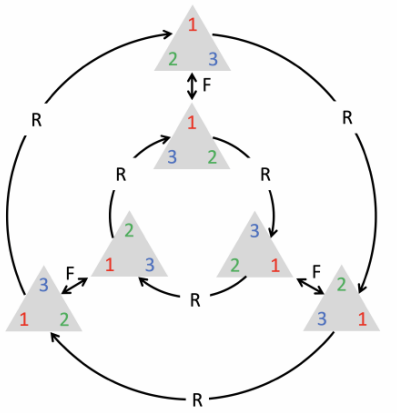
群作用与群表示 我们最感兴趣的不是作为抽象实体的群，而是群如何作用于数据。由于我们假定数据底层有一个定义域 Ω，便将研究群如何作用于 Ω（例如平面上点的平移），进而得到同一个群在信号空间 $\mathcal{X}(\Omega)$ 上的作用（例如平面图像和特征图的平移）。

示群元素，因为这种字体常用于表示李代数。

[5]以挪威数学家 Niels Henrik Abel（1802–1829）的名字命名。

[6]李群具有可微流形结构。我们将在第 4.3 节研究的特例之一是特殊正交群 $SO(3)$，它是一个三维流形。

[7]图 4 所示的图中，每个节点对应一个群元素，每条箭头对应一个生成元；这种图称为凯莱图。



	id	R	R^2	F	FR	FR^2
id	id	R	R^2	F	FR	FR^2
R	R	R^2	id	RF	RFR	RFR^2
R^2	R^2	id	R	R^2F	R^2FR	R^2FR^2
F	F	FR	FR^2	id	R	FR
FR	FR	FR^2	F	FRF	FRFR	$FRFR^2$
FR^2	FR^2	F	FR	FR^2F	FR^2FR	FR^2FR^2

图 4: 左：顶点标为 1、2、3 的正三角形及其所有可能的旋转和反射。三角形旋转 / 反射对称群 D_3 仅由两个元素（$60°$ 旋转 R 和反射 F）生成，并且与三个元素的置换群 Σ_3 相同。右：群 D_3 的乘法表。第 $\mathfrak{g}$ 行、第 $\mathfrak{h}$ 列的元素对应于 $\mathfrak{gh}$。

群 $\mathfrak{G}$ 在集合 Ω 上的作用定义为映射 $(\mathfrak{g}, u) \mapsto \mathfrak{g}.u$，它将群元素 $\mathfrak{g} \in \mathfrak{G}$ 和点 $u \in \Omega$ 对应到 Ω 上另一点，并与群运算相容，即对所有 $\mathfrak{g}, \mathfrak{h} \in \mathfrak{G}$ 和 $u \in \Omega$，有 $\mathfrak{g}.(\mathfrak{h}.u) = (\mathfrak{gh}).u$。[8]下文将看到许多群作用的例子。例如，平面上的欧几里得群 $E(2)$ 是保持欧几里得距离的 $\mathbb{R}^2$ 变换群，由平移、旋转和反射组成。[9]然而，同一个群也可以作用在平面图像空间上（通过平移、旋转和翻转像素网格），以及神经网络所学的表示空间上。更确切地说，如果群 $\mathfrak{G}$ 作用于 Ω，我们便自动得到 $\mathfrak{G}$ 在空间 $\mathcal{X}(\Omega)$ 上的作用：

$$(\mathfrak{g}.x)(u) = x(\mathfrak{g}^{-1}u). \tag{3}$$

由于使用了 $\mathfrak{g}$ 的逆元，这确为群作用，满足 $(\mathfrak{g}.(\mathfrak{h}.x))(u) = ((\mathfrak{gh}).x)(u)$。

我们将在全文中反复遇到的最重要一类群作用是线性群作用，也称为群表示。式 (3) 中对信号的作用确实是线性的，即对任意标量 α, β 和信号

[8]严格来说，此处定义的是左群作用。

[9]保持距离的变换称为等距变换。根据克莱因的埃尔朗根纲领，经典欧几里得几何来自这个群。

$x, x' \in \mathcal{X}(\Omega)$，有

$$\mathfrak{g}.(\alpha x + \beta x') = \alpha(\mathfrak{g}.x) + \beta(\mathfrak{g}.x').$$

我们既可以将线性作用描述为对 x 线性的映射 $(\mathfrak{g}, x) \mapsto \mathfrak{g}.x$，也可以通过柯里化等价地描述为映射 $\rho : \mathfrak{G} \to \mathbb{R}^{n\times n}$，它为每个群元素 $\mathfrak{g}$ 指定一个（可逆）矩阵 $\rho(\mathfrak{g})$。矩阵的维数 n 一般是任意的，不一定与群或 Ω 的维数有关；但在深度学习应用中，n 通常是群所作用的特征空间的维数。例如，二维平移群可以作用于具有 n 个像素的图像空间。[10]

与一般群作用一样，将矩阵赋给群元素的方式应当与群作用相容。具体而言，表示复合群元素 $\mathfrak{gh}$ 的矩阵应等于 $\mathfrak{g}$ 和 $\mathfrak{h}$ 的表示矩阵之积：群 $\mathfrak{G}$ 的 n 维实表示是映射 $\rho : \mathfrak{G} \to \mathbb{R}^{n\times n}$，它为每个 $\mathfrak{g} \in \mathfrak{G}$ 指定一个可逆矩阵 $\rho(\mathfrak{g})$，并对所有 $\mathfrak{g}, \mathfrak{h} \in \mathfrak{G}$ 满足 $\rho(\mathfrak{gh}) = \rho(\mathfrak{g})\rho(\mathfrak{h})$。如果对所有 $\mathfrak{g} \in \mathfrak{G}$，矩阵 $\rho(\mathfrak{g})$ 都是酉矩阵或正交矩阵，则相应地称该表示为酉表示或正交表示。[11]

用群表示的语言，$\mathfrak{G}$ 在信号 $x \in \mathcal{X}(\Omega)$ 上的作用定义为 $\rho(\mathfrak{g})x(u) = x(\mathfrak{g}^{-1}u)$。我们再次验证，$(\rho(\mathfrak{g})(\rho(\mathfrak{h})x))(u) = (\rho(\mathfrak{gh})x)(u)$。

不变函数与等变函数 信号 $\mathcal{X}(\Omega)$ 底层定义域 Ω 的对称性，会对定义在这些信号上的函数 f 施加结构。这是一种强有力的归纳偏置：它将可能的插值函数空间 $\mathcal{F}(\mathcal{X}(\Omega))$ 缩减为满足对称性先验的函数，从而提高学习效率。[12]本文将研究两个重要情形：不变函数和等变函数。

若函数 $f : \mathcal{X}(\Omega) \to \mathcal{Y}$ 对所有 $\mathfrak{g} \in \mathfrak{G}$ 和 $x \in \mathcal{X}(\Omega)$ 满足 $f(\rho(\mathfrak{g})x) = f(x)$，则称其为 $\mathfrak{G}$-不变的，即输入上的群作用不影响输出。

不变性的一个经典例子是平移不变性，它出现在计算机视觉和模式识别应用中，例如图像分类。[13]此时函数 f（通常由卷积神经网络实现）输入图像，输出图像包含某一类别物体（例如猫或狗）的概率。人们通常有理由假

[10]当 Ω 无限时，信号空间 $\mathcal{X}(\Omega)$ 是无限维的，此时 $\rho(\mathfrak{g})$ 是该空间上的线性算子，而非有限维矩阵。不过在实践中，总需要离散化到有限网格。

[11]类似地，复表示是满足同一等式的映射 $\rho : \mathfrak{G} \to \mathbb{C}^{n\times n}$。

[12]一般来说，f 同时依赖于信号和定义域，即 $\mathcal{F}(\mathcal{X}(\Omega), \Omega)$。为简洁起见，我们常省略后一项依赖。

[13]注意，信号处理书籍经常用“平移不变性”指平移等变性，例如线性平移不变系统。

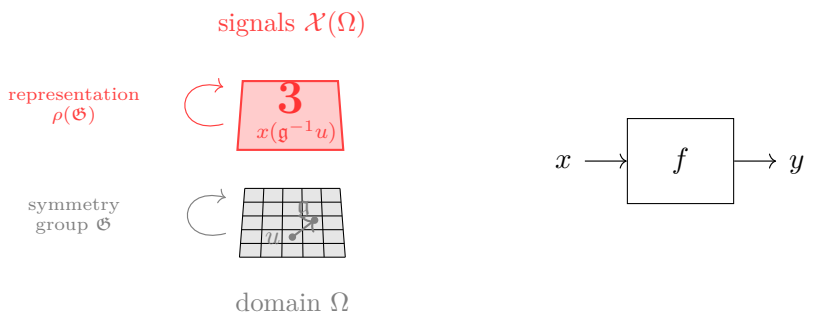


图 5: 几何深度学习中关注的三个空间：（物理）定义域 Ω、信号空间 $\mathcal{X}(\Omega)$ 和假设类 $\mathcal{F}(\mathcal{X}(\Omega))$。定义域 Ω 的对称性（由群 $\mathfrak{G}$ 刻画）通过群表示 $\rho(\mathfrak{g})$ 作用于信号 $x \in \mathcal{X}(\Omega)$，从而对作用在这些信号上的函数 $f \in \mathcal{F}(\mathcal{X}(\Omega))$ 施加结构。

定分类结果不应受物体在图像中位置的影响，即 f 必须具有平移不变性。能够逼近任意光滑函数的多层感知机并不具有这一性质，这是 20 世纪 70 年代早期将其应用于模式识别问题的尝试失败的原因之一。以卷积神经网络为代表的局部权重共享神经网络架构，其发展动机之一正是需要具有平移不变性的物体分类。

然而，仔细考察 CNN 的卷积层会发现，它们不是平移不变而是平移等变的：换言之，平移卷积层的输入，会使输出特征图平移相同的距离。

若函数 $f : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega)$ 对所有 $\mathfrak{g} \in \mathfrak{G}$ 满足 $f(\rho(\mathfrak{g})x) = \rho(\mathfrak{g})f(x)$，则称其为 $\mathfrak{G}$-等变的，即输入上的群作用以相同方式影响输出。[14]

再次借助计算机视觉，要求平移等变性的典型应用是图像分割，此时 f 的输出是逐像素图像掩膜。显然，分割掩膜必须跟随输入图像的平移。在这个例子中，输入和输出的定义域相同，但由于输入有三个颜色通道，而输出对每个类别有一个通道，表示 $(\rho, \mathcal{X}(\Omega, \mathcal{C}))$ 与 $(\rho', \mathcal{X}(\Omega, \mathcal{C}'))$ 略有不同。

然而，即使前面图像分类的例子，通常也是以一系列卷积（平移等变）层、后接全局池化（平移不变）来实现的。如第 3.5 节所示，这是包括 CNN 和图神经网络（GNN）在内的大多数深度学习架构的一般蓝图。

[14] 更一般地，可能有 $f : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega')$，输入和输出空间具有不同定义域 Ω, Ω'，以及同一群 $\mathfrak{G}$ 的表示 ρ, ρ'。此时等变性定义为 $f(\rho(\mathfrak{g})x) = \rho'(\mathfrak{g})f(x)$。

3.2 同构与自同构

子群与结构的层次 如前所述，对称性是保持某种性质或结构的变换，而对于给定结构，所有此类变换构成一个对称群。[15]我们关注的结构常常不止一种，因此可以考虑定义域 Ω 上结构的若干层次。于是，什么算作对称性取决于所考虑的结构，但无论哪种情况，对称性都是尊重这一结构的可逆映射。

在最基本的层次上，定义域 Ω 是一个集合，具有最少的结构：我们只能说这个集合具有某个基数。[16]保持这一结构的自映射是双射（可逆映射），可以视为集合层次的对称性。通过检验公理容易验证它们构成一个群：两个双射的复合仍是双射（封闭性）；结合律源于函数复合的结合律；映射 $\tau(u) = u$ 是单位元；而对每个 τ，依定义都存在逆映射，满足 $(\tau \circ \tau^{-1})(u) = (\tau^{-1} \circ \tau)(u) = u$。

根据具体应用，还可能有进一步的结构层次。例如，若 Ω 是拓扑空间，可以考虑保持连续性的映射：这类映射称为同胚，除了是集合间的双射，还连续且具有连续的逆映射。直观地说，连续函数性质良好，将某点 u 周围邻域（开集）中的点映射到 $\tau(u)$ 周围的邻域中。

还可以进一步要求映射及其逆映射都是（连续）可微的，即二者在每一点都有导数（并且导数也连续）。[17]这要求具有可微流形所带有的进一步可微结构；这类映射称为微分同胚，记为 $\mathrm{Diff}(\Omega)$。我们还将遇到的其他结构包括距离或度量（保持距离的映射称为等距映射）以及定向（据我们所知，保持定向的映射没有通用的希腊名称）。

度量或距离是函数 $d : \Omega \times \Omega \to [0, \infty)$，对所有 $u, v, w \in \Omega$ 满足：

不可分辨者的同一性 $d(u, v) = 0$ 当且仅当 $u = v$。

对称性 $d(u, v) = d(v, u)$。

三角不等式 $d(u, v) \leq d(u, w) + d(w, v)$。

赋有度量的空间 (Ω, d) 称为度量空间。

---

[15]不同对象之间可逆且保持结构的映射通常统称为同构（希腊语意为“形状相同”）。对象到自身的同构称为自同构，或对称性。

[16]对于有限集合，基数是集合中元素的个数（“大小”）；对于无限集合，基数表明不同种类的无穷，如自然数的可数无穷，或连续统 $\mathbb{R}$ 的不可数无穷。

[17]每个可微函数都是连续的。若映射连续可微“足够多次”，则称其为光滑的。

应该考虑何种结构层次取决于问题。例如，分割组织病理学切片图像时，我们可能希望把图像的翻转版本视为等价（因为样本放到显微镜下时可以翻转）；但如果要对道路标志进行分类，则只希望把保持定向的变换视为对称性，因为反射可能改变标志的含义。

随着需要保持的结构层次增加，对称群会变小。事实上，增加结构相当于选择一个子群：它是较大群的一个子集，并且自身满足群公理。设 $(\mathfrak{G}, \circ)$ 为群，$\mathfrak{H} \subseteq \mathfrak{G}$ 为子集。若 $(\mathfrak{H}, \circ)$ 在相同运算下构成群，就称 $\mathfrak{H}$ 为 $\mathfrak{G}$ 的子群。

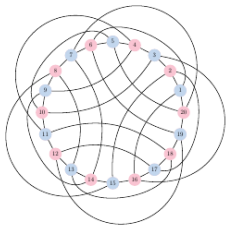
例如，欧几里得等距变换群 $E(2)$ 是平面微分同胚群 $\mathrm{Diff}(2)$ 的子群，而保持定向的等距变换群 $SE(2)$ 又是 $E(2)$ 的子群。这一结构层次遵循前言中概述的埃尔朗根纲领哲学：在克莱因的构造中，射影几何、仿射几何和欧几里得几何具有越来越多的不变量，并对应于逐渐变小的群。

同构与自同构 我们将对称性描述为对象到自身的保持结构的可逆映射。这类映射又称为自同构，描述对象与自身等价的一种方式。然而，同样重要的另一类映射是所谓的同构，它展示两个不相同对象之间的等价关系。这些概念常被混为一谈，但为了使后续讨论清晰，有必要区分它们。

为理解二者的区别，考虑集合 $\Omega = \{0, 1, 2\}$。集合 Ω 的自同构是双射 $\tau : \Omega \to \Omega$，例如循环平移 $\tau(u) = u + 1 \pmod 3$。这种映射保持基数性质，并将 Ω 映到自身。若另有具有相同元素个数的集合 $\Omega' = \{a, b, c\}$，则双射 $\eta : \Omega \to \Omega'$（例如 $\eta(0) = a$、$\eta(1) = b$、$\eta(2) = c$）是集合的同构。

正如我们将在第 4.1 节中对图所见，结构的概念不仅包括节点数，还包括连接关系。因此，两个图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 与 $\mathcal{G}' = (\mathcal{V}', \mathcal{E}')$ 之间的同构 $\eta : \mathcal{V} \to \mathcal{V}'$ 是节点间的双射，它将相连的节点对映为相连的节点对，对不相连的节点对也同样如此。[18]因此，同构的图在结构上完全相同，只是节点排列方式不同。另一方面，图的自同构或对称性是将图节点映回自身并保持连接关系的映射 $\tau : \mathcal{V} \to \mathcal{V}$。具有非平凡自同构（即 $\tau \neq \mathrm{id}$）的图具有对称性。

[18]即 $(\eta(u), \eta(v)) \in \mathcal{V}'$ 当且仅当 $(u, v) \in \mathcal{V}$。

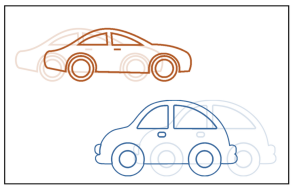


Folkman 图（Folkman，1967）是具有 3840 个自同构的图的一个优美例子；绘制它的许多对称方式体现了这一点。

3.3 形变稳定性

第 3.1–3.2 节引入的对称性形式体系刻画了一个理想化世界：我们确切知道哪些变换应当视为对称性，并希望严格保持这些对称性。例如，在计算机视觉中，我们可以假定平面平移是严格的对称性。然而，现实世界有噪声，这一模型在两个方面有所不足。

首先，虽然这些简单的群提供了理解定义域 Ω（以及其上信号 $\mathcal{X}(\Omega)$）全局对称性的方法，却不能很好地捕捉局部对称性。例如，考虑一个视频场景，其中几个物体各自沿不同方向运动。在后续帧中，得到的场景将包含大致相同的语义信息，但没有任何全局平移能够解释帧与帧之间的变换。在其他情况下，例如摄像机观察到一个可形变的三维物体时，要描述保持物体身份的变换群本身就十分困难。这些例子说明，现实中我们更关心范围大得多的一组变换，其中全局的、精确的不变性被局部的、近似的不变性取代。下文将区分两种情形：定义域 Ω 固定而信号 $x \in \mathcal{X}(\Omega)$ 发生形变；以及定义域 Ω 本身可能发生形变。



视频中以不同速度运动的两个物体定义了一个平移群之外的变换。

信号形变的稳定性 在许多应用中，我们先验地知道信号 x 的微小形变不应改变 $f(x)$ 的输出，因此很容易想到把这类形变视为对称性。例如，可以把微小的微分同胚 $\tau \in \mathrm{Diff}(\Omega)$，甚至微小的双射视为对称性。然而，微小形变复合后可以形成大形变，因此“微小形变”不构成群，我们不能只要求对微小形变具有不变性或等变性。[19]由于大形变实际上可能实质性地改变输入的语义内容，将整个群 $\mathrm{Diff}(\Omega)$ 作为对称群也不是好办法。

更好的方法是用复杂度度量 $c(\tau)$ 量化给定 $\tau \in \mathrm{Diff}(\Omega)$ 距离给定对称子群 $\mathfrak{G} \subset \mathrm{Diff}(\Omega)$（例如平移群）有多“远”，使得当 $\tau \in \mathfrak{G}$ 时 $c(\tau) = 0$。这样，就可以将先前关于群作用的精确不变性和等变性定义，替换为一种较“软”的形变稳定性（或近似不变性）概念：

$$\|f(\rho(\tau)x) - f(x)\| \leq Cc(\tau)\|x\|, \qquad \forall x \in \mathcal{X}(\Omega), \tag{4}$$

其中与前文一样，$\rho(\tau)x(u) = x(\tau^{-1}u)$，$C$ 是与信号 x 无关的常数。满足上式的函数 $f \in \mathcal{F}(\mathcal{X}(\Omega))$ 称为几何稳定的。下一节将给出这类函数的例子。

由于对 $\tau \in \mathfrak{G}$ 有 $c(\tau) = 0$，这一定义推广了上述 $\mathfrak{G}$-不变性。它在应用中的效用取决于引入恰当的形变代价。对于定义在连续欧几里得平面上的图像，一个常见选择是 $c^2(\tau) := \int_\Omega \|\nabla\tau(u)\|^2\, du$，它衡量 τ 的“弹性”，即它与常向量场产生的位移相差多大。这个形变代价实际上是一个常称为狄利克雷能量的范数，可用于量化 τ 与平移群的距离。

定义域形变的稳定性 在许多应用中，发生形变的对象不是信号，而是几何定义域 Ω 本身。典型例子是处理图和流形的应用：图可以模拟不同时刻、社会关系略有不同的社交网络（关注关系图）；流形可以模拟发生非刚性形变的三维物体。可以如下量化这种形变。若 $\mathcal{D}$ 表示所有可能的可变定义域构成的空间（例如所有图的空间，或黎曼流形的空间），则可对 $\Omega, \widetilde{\Omega} \in \mathcal{D}$ 定义适当的度量（“距离”）$d(\Omega, \widetilde{\Omega})$，使得当 Ω 和 $\widetilde{\Omega}$ 在某种意义下等价时 $d(\Omega, \widetilde{\Omega}) = 0$：例如，图同构时图编辑距离为零；赋有测地距离的黎曼流形在等距时，其 Gromov–Hausdorff 距离为零。[20]

[19]例如，两个 ϵ-等距映射的复合是一个 2ϵ-等距映射，违反封闭性。

[20]图编辑距离衡量通过一系列图编辑操作使两个图同构的最小代价。Gromov–Hausdorff 距离衡量两个度量空间之间对应关系可能达到的最小度量失真，见 Gromov（1981）。

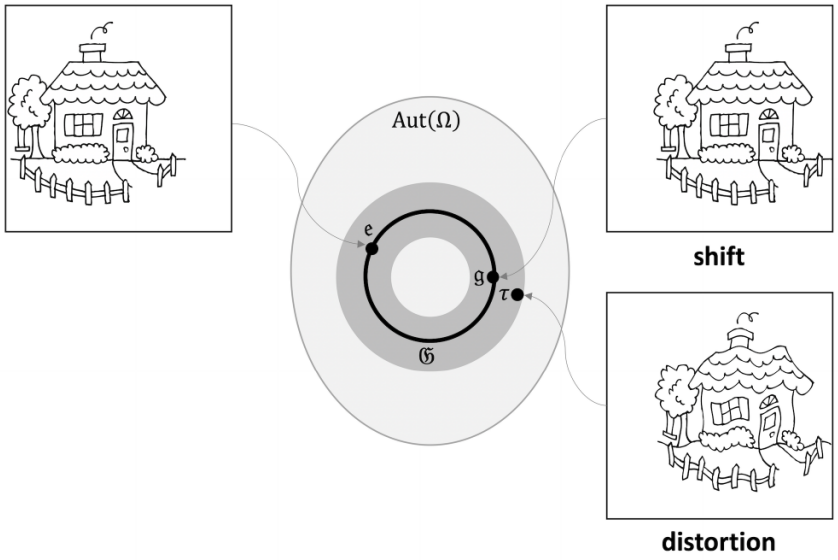


图 6: 从 Ω 到自身的所有双射构成集合自同构群 $\mathrm{Aut}(\Omega)$，其对称群 $\mathfrak{G}$（以圆表示）是一个子群。几何稳定性将 $\mathfrak{G}$-不变性和等变性的概念推广到“$\mathfrak{G}$ 附近的变换”（以灰色环表示），并用变换之间的某种度量加以量化。在本例中，图像的光滑扭曲接近平移。

构造这类定义域间距离的一种常见方法，依赖于一族可逆映射 $\eta : \Omega \to \widetilde{\Omega}$，试图“对齐”定义域，使相应结构得到最佳保持。例如，对图或黎曼流形（视为赋有测地距离的度量空间），这种对齐可以分别比较成对邻接结构或距离结构 d 和 $\widetilde{d}$:

$$d_{\mathcal{D}}(\Omega, \widetilde{\Omega}) = \inf_{\eta \in \mathfrak{G}} \|d - \widetilde{d} \circ (\eta \times \eta)\|,$$

其中 $\mathfrak{G}$ 是同构群，例如双射或等距映射；范数定义在乘积空间 $\Omega \times \Omega$ 上。换言之，通过考虑所有保持内部结构的可能对齐，$\Omega, \widetilde{\Omega}$ 中元素之间的距离被“提升”为定义域本身之间的距离。给定信号 $x \in \mathcal{X}(\Omega)$ 和形变后的定义域 $\widetilde{\Omega}$，便可以考虑形变后的信号 $\widetilde{x} = x \circ \eta^{-1} \in \mathcal{X}(\widetilde{\Omega})$。[21]

稍微滥用记号，我们定义 $\mathcal{X}(\mathcal{D}) = \{(\mathcal{X}(\Omega), \Omega) : \Omega \in \mathcal{D}\}$ 为定义在可变定义域上的所有可能输入信号的集合。若对所有 $\Omega, \widetilde{\Omega} \in \mathcal{D}$ 和 $x \in \mathcal{X}(\Omega)$，函数 $f : \mathcal{X}(\mathcal{D}) \to \mathcal{Y}$ 满足

$$\|f(x, \Omega) - f(\widetilde{x}, \widetilde{\Omega})\| \leq C\|x\| d_{\mathcal{D}}(\Omega, \widetilde{\Omega}), \tag{5}$$

则称其对定义域形变稳定。我们将在第 4.4–4.6 节的流形背景下讨论这一稳定性概念，届时等距形变将发挥关键作用。此外，可以表明，通过从体积形式形变的角度看待信号形变，定义域形变稳定性是信号形变稳定性的自然推广（Gama et al.，2019）。

3.4 尺度分离

虽然形变稳定性大大加强了全局对称性先验，但它本身不足以克服维数灾难：非正式地说，随着定义域大小增长，满足式 (4) 的函数仍然“太多”。克服这一灾难的关键认识是利用物理任务的多尺度结构。在描述多尺度表示之前，我们需要先介绍傅里叶变换的主要要素；傅里叶变换依赖频率而非尺度。

[21]两个图可以通过二次指派问题（QAP）对齐。其最简单形式考虑大小均为 n 的两个图 $G, \widetilde{G}$，并求解 $\min_{P \in \Sigma_n} \operatorname{trace}(AP\widetilde{A}P^{\top})$，其中 $A, \widetilde{A}$ 是各自的邻接矩阵，Σ_n 是 $n \times n$ 置换矩阵群。图编辑距离可以与这种 QAP 联系起来（Bougleux et al.，2015）。

傅里叶变换与全局不变量 最著名的信号分解或许是傅里叶变换，它是调和分析的基石。经典的一维傅里叶变换

$$\widehat{x}(\xi) = \int_{-\infty}^{+\infty} x(u) e^{-i\xi u}\, du$$

将定义域 $\Omega = \mathbb{R}$ 上的函数 $x(u) \in L^2(\Omega)$ 表示为正交振荡基函数 $\phi_\xi(u) = e^{i\xi u}$ 的线性组合；这些基函数按振荡速率（或频率）ξ 索引。[22]这种按频率组织的方式揭示了信号的重要信息，例如其光滑性和局域化。傅里叶基本身具有深刻的几何基础，可以解释为与定义域几何结构有关的自然振动（例如 Berger（2012））。

傅里叶变换在信号处理中起关键作用，因为它给出了卷积的对偶表述：

$$(x \star \theta)(u) = \int_{-\infty}^{+\infty} x(v)\theta(u-v)\, dv.$$

卷积是线性信号滤波的标准模型（此处及下文中，x 表示信号，θ 表示滤波器）。[23]如下文所示，卷积算子在傅里叶基下被对角化，因而可以将卷积表示为各自傅里叶变换的乘积：

$$\widehat{(x \star \theta)}(\xi) = \widehat{x}(\xi) \cdot \widehat{\theta}(\xi),$$

这一事实在信号处理中称为卷积定理。

许多基本微分算子，如拉普拉斯算子，在欧几里得定义域上都可以描述为卷积。由于这类微分算子可以在非常一般的几何上内禀定义，这提供了将傅里叶变换扩展到欧几里得空间之外的形式化方法，包括图、群和流形。我们将在第 4.4 节详细讨论。

傅里叶变换的一个重要方面是揭示信号和定义域的全局性质，如光滑性或电导。在定义域具有平移等全局对称性时，这种全局行为很方便，但它不适合研究更一般的微分同胚。为此需要在空间局域化和频率局域化之间作权衡的表示，如下所示。

---

[22]傅里叶基函数具有全局支撑。因此，局域信号在所有频率上都产生能量。

[23]遵循机器学习中的常见做法，下文将交替使用卷积与（互）相关 $(x \star \theta)(u) = \int_{-\infty}^{+\infty} x(v)\theta(u+v)\, dv$：二者的区别在于是否反转滤波器，而滤波器通常是可学习的，因此区别仅在于记号。

多尺度表示 从基于傅里叶频率的表示转向基于尺度的表示，可以阐明局部不变性的概念；后者是小波等多尺度分解方法的基石。[24]多尺度方法的核心思想，是将定义域 Ω 上的函数分解为在空间和频率上都局域化的基本函数。对于小波，这通过与平移并伸缩的滤波器（母小波）ψ 作相关来实现，得到称为连续小波变换的空间—频率联合表示：

$$(W_\psi x)(u,\xi) = \xi^{-1/2} \int_{-\infty}^{+\infty} \psi\left(\frac{v-u}{\xi}\right) x(v)\, dv.$$

平移并伸缩后的滤波器称为小波原子，其空间位置和伸缩对应小波变换的坐标 u 和 ξ。这些坐标通常以二进方式采样（$\xi = 2^{-j}$、$u = 2^{-j}k$），其中 j 称为尺度。[25]多尺度信号表示在捕捉超越全局光滑性的正则性性质（例如分段光滑性）方面具有重要优势，因此在 20 世纪 90 年代成为信号与图像处理和数值分析中的常用工具。

多尺度表示的形变稳定性 考察底层对称群“附近”的微小形变的影响时，多尺度局域小波分解相对于傅里叶分解的优势便显现出来。我们在欧几里得定义域和平移群的情形中说明这一重要概念。由于傅里叶表示将平移算子对角化（该算子可以视为卷积，第 4.2 节将更详细说明），它是处理平移变换的一种高效表示。然而，傅里叶分解在高频形变下不稳定；相比之下，小波分解在这种情况下提供稳定的表示。

具体而言，考虑 $\tau \in \mathrm{Aut}(\Omega)$ 及其相应线性表示 $\rho(\tau)$。当 $\tau(u) = u - v$ 是平移时，如第 4.2 节将验证的，算子 $\rho(\tau) = S_v$ 是与卷积可交换的平移算子。由于傅里叶变换将卷积算子对角化，频域中的平移作用相当于改变傅里叶变换的复相位：

$$\widehat{(S_v x)}(\xi) = e^{-i\xi v} \widehat{x}(\xi).$$

因此，去掉复相位的傅里叶模 $f(x) = |\widehat{x}|$ 是一个简单的平移不变函数，$f(S_v x) = f(x)$。然而，如果只有近似平移，即 $\tau(u) = u - \widetilde{\tau}(u)$ 且 $\|\nabla\tau\|_\infty =$

[24]全面介绍见 Mallat（1999）。

[25]与傅里叶方法不同，小波原子是局域且多尺度的：空间支撑小的原子可捕捉信号的精细细节，支撑大的原子可捕捉粗略细节。此处“原子”与傅里叶分析中的“基元素”同义，但须注意小波是冗余的（过完备的）。

$\sup_{u\in\Omega}\|\nabla\tilde{\tau}(u)\|\leq\epsilon$，情形便完全不同：可以证明

$$\frac{\|f(\rho(\tau)x)-f(x)\|}{\|x\|}=O(1),$$

而不论 ϵ 有多小（即 τ 多么接近平移）。因此，这种傅里叶表示在任意小的形变下都不稳定。这种不稳定性也会在一般定义域和非刚性变换中表现出来；在第 4.4 节使用傅里叶变换的自然推广分析三维形状时，我们将看到另一例子。

小波为这一问题提供了解决办法，也展示了多尺度表示的力量。在上述例子中，可以证明（Mallat，2012）小波分解 $W_\psi x$ 对形变近似等变：

$$\frac{\|\rho(\tau)(W_\psi x)-W_\psi(\rho(\tau)x)\|}{\|x\|}=O(\epsilon).$$

[26]换言之，利用局域滤波器按尺度而非频率分解信号信息，可将全局不稳定的表示变成一族局部稳定的特征。重要的是，不同尺度上的这类测量还不具有不变性，需要逐步向低频处理；这暗示了现代神经网络深度复合的性质，也体现在下文给出的几何深度学习蓝图中。

尺度分离先验 沿着这一思路，可以将数据定义域 Ω 多尺度粗化为层次 $\Omega_1,\dots,\Omega_J$。这种粗化可以定义在非常一般的定义域上，包括网格、图和流形。非正式地说，粗化将邻近的点 $u,u'\in\Omega$ 归并，因此只要求定义域中有适当的度量概念。若 $\mathcal{X}_j(\Omega_j,\mathcal{C}_j):=\{x_j:\Omega_j\to\mathcal{C}_j\}$ 表示定义在粗化域 Ω_j 上的信号，当函数 $f:\mathcal{X}(\Omega)\to\mathcal{Y}$ 可分解为 $f\approx f_j\circ P_j$ 时，我们非正式地称它在尺度 j 上局部稳定；其中 $P_j:\mathcal{X}(\Omega)\to\mathcal{X}_j(\Omega_j)$ 是非线性粗粒化，$f_j:\mathcal{X}_j(\Omega_j)\to\mathcal{Y}$。换言之，虽然目标函数 f 可能依赖整个定义域上特征之间复杂的长程相互作用，但对于局部稳定函数，可以将不同尺度的相互作用分离：先关注局部相互作用，再将其向粗尺度传播。

这些原理在物理学和数学的许多领域具有根本重要性，例如体现在统计物理中的重整化群，或被用于快速多极子方法等重要数值算法。[27]在机器学

[26]这一记号表示 $\rho(\tau)$ 作用于 $(W_\psi x)(u,\xi)$ 的空间坐标。

[27]快速多极子方法（FMM）是一种数值技术，最初用于加速 n 体问题中长程力的计算。FMM 将彼此靠近的源分组，并将它们视为一个源。

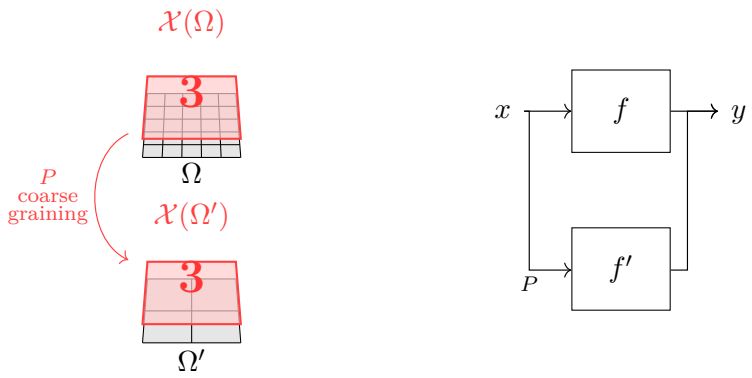


图 7: 图像分类任务中的尺度分离示意。定义在粗网格信号 $\mathcal{X}(\Omega')$ 上的分类器 f' 应满足 $f \approx f' \circ P$，其中 $P : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega')$。

习中，多尺度表示和局部不变性是支撑卷积神经网络和图神经网络效率的基本数学原理，通常以局部池化实现。在未来的工作中，我们将进一步发展计算调和分析工具，在各类几何定义域上统一这些原理，并阐明尺度分离在统计学习方面带来的益处。

3.5 几何深度学习蓝图

第 3.1–3.4 节讨论的对称性、几何稳定性和尺度分离等几何原理可以结合起来，为高维数据稳定表示的学习提供一个普适蓝图。这些表示由作用于信号空间 $\mathcal{X}(\Omega, \mathcal{C})$ 的函数 f 产生；信号定义在赋有对称群 $\mathfrak{G}$ 的定义域 Ω 上。

到目前为止，我们描述的几何先验没有规定构建这种表示的特定架构，而是给出一系列必要条件。然而，它们暗示了一种公理化构造：可以证明该构造满足这些几何先验，同时保证表示具有很强的表达能力，能够逼近满足这些先验的任意目标函数。

一个简单的初步观察是：要获得表达能力很强的表示，必须引入非线性元素。因为如果 f 是线性且 $\mathfrak{G}$-不变的，那么对所有 $x \in \mathcal{X}(\Omega)$，都有[28]

$$f(x) = \frac{1}{\mu(\mathfrak{G})} \int_{\mathfrak{G}} f(\mathfrak{g}.x)\, d\mu(\mathfrak{g}) = f\left(\frac{1}{\mu(\mathfrak{G})} \int_{\mathfrak{G}} (\mathfrak{g}.x)\, d\mu(\mathfrak{g}) \right),$$

[28]这里的 $\mu(\mathfrak{g})$ 称为群 $\mathfrak{G}$ 的 Haar 测度，积分在整个群上进行。

这表明 f 只通过 $\mathfrak{G}$-平均 $Ax = \frac{1}{\mu(\mathfrak{G})}\int_{\mathfrak{G}}(\mathfrak{g}.x)\,d\mu(\mathfrak{g})$ 依赖于 x。对于图像和平移，这意味着只能使用输入的平均 RGB 颜色！

虽然这一推理表明线性不变量族不是一个很丰富的对象，线性等变量族却提供了强大得多的工具，因为通过与适当的非线性映射复合，它可以构造丰富而稳定的特征。事实上，若 $B : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{X}(\Omega, \mathcal{C}')$ 是 $\mathfrak{G}$-等变的，对所有 $x \in \mathcal{X}$ 和 $\mathfrak{g} \in \mathfrak{G}$ 满足 $B(\mathfrak{g}.x) = \mathfrak{g}.B(x)$，而 $\sigma : \mathcal{C}' \to \mathcal{C}''$ 是任意（非线性）映射，那么容易验证复合 $U := (\sigma \circ B) : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{X}(\Omega, \mathcal{C}'')$ 也是 $\mathfrak{G}$-等变的；其中 $\sigma : \mathcal{X}(\Omega, \mathcal{C}') \to \mathcal{X}(\Omega, \mathcal{C}'')$ 是 σ 的逐点实现，即 $(\sigma(x))(u) := \sigma(x(u))$。

这一简单性质允许我们通过将 U 与群平均复合，定义非常一般的 $\mathfrak{G}$-不变量族 $A \circ U : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{C}''$。一个自然的问题是：对适当选择的 B 和 σ，这种模型是否能以任意精度逼近任何 $\mathfrak{G}$-不变函数？适当地将群平均推广为一般非线性不变量后，不难将无结构向量输入的标准普适逼近定理加以修改，表明浅层“几何”网络也是普适逼近器。[29]

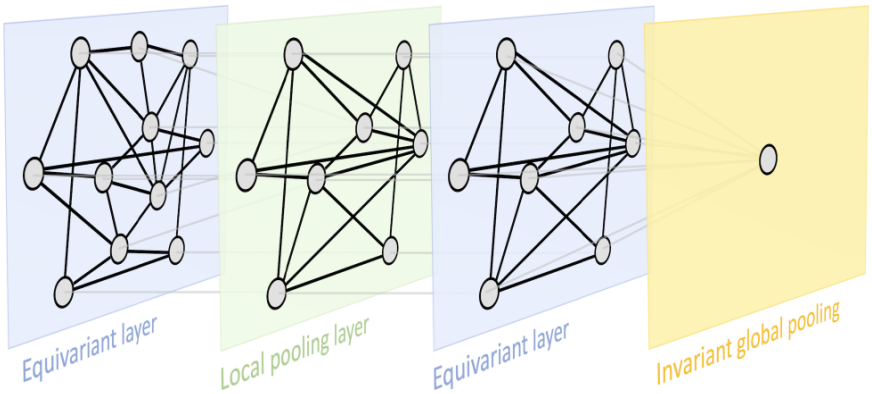


图 8: 以图为例的几何深度学习蓝图。典型的图神经网络架构可以包含置换等变层（计算逐节点特征）、局部池化（图粗化）以及置换不变的全局池化层（读出层）。

然而，正如前面讨论傅里叶不变量与小波不变量时所述，浅层全局不变性与形变稳定性之间存在根本张力。这促使我们转而考虑局域等变映射，构造另一种表示。假定 Ω 还赋有距离度量 d，若 $(Ux)(u)$ 仅依赖于 $\mathcal{N}_u = \{v :$

[29]例如，Zaheer et al.（2017）已为 Deep Sets 模型给出这类证明。

$d(u,v) \le r\}$ 中的 $x(v)$ 值，其中半径 r 较小，则称等变映射 U 为局域的；集合 $\mathcal{N}_u$ 称为感受野。[30]

单层局域等变映射 U 不能逼近具有长程相互作用的函数，但多个局域等变映射的复合 $U_J \circ U_{J-1} \cdots \circ U_1$ 可以在保持局域等变映射稳定性性质的同时扩大感受野。[31]通过交错加入粗化定义域的下采样算子（再次假定具有度量结构），感受野还可以进一步扩大，完成与多分辨率分析（MRA，参见例如 Mallat（1999））的类比。

总之，输入定义域的几何及其底层对称群提供三个关键构件：（i）局域等变映射；（ii）全局不变映射；（iii）粗化算子。将这些构件组合在一起，可提供具有指定不变性和稳定性性质的丰富函数逼近空间；我们将这一方案称为几何深度学习蓝图（图 8）。

几何深度学习蓝图

设 Ω 和 Ω' 为定义域，$\mathfrak{G}$ 为 Ω 上的对称群；若 Ω' 可以视为 Ω 的紧缩版本，就记作 $\Omega' \subseteq \Omega$。定义以下构件：

线性 $\mathfrak{G}$-等变层 $B : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{X}(\Omega', \mathcal{C}')$，对所有 $\mathfrak{g} \in \mathfrak{G}$ 和 $x \in \mathcal{X}(\Omega, \mathcal{C})$ 满足 $B(\mathfrak{g}.x) = \mathfrak{g}.B(x)$。

非线性 $\sigma : \mathcal{C} \to \mathcal{C}'$，逐点作用为 $(\sigma(x))(u) = \sigma(x(u))$。

局部池化（粗化） $P : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{X}(\Omega', \mathcal{C})$，其中 $\Omega' \subseteq \Omega$。

$\mathfrak{G}$-不变层（全局池化） $A : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{Y}$，对所有 $\mathfrak{g} \in \mathfrak{G}$ 和 $x \in \mathcal{X}(\Omega, \mathcal{C})$ 满足 $A(\mathfrak{g}.x) = A(x)$。

利用这些构件可以构造如下形式的 $\mathfrak{G}$-不变函数 $f : \mathcal{X}(\Omega, \mathcal{C}) \to \mathcal{Y}$：

$$f = A \circ \sigma_J \circ B_J \circ P_{J-1} \circ \cdots \circ P_1 \circ \sigma_1 \circ B_1,$$

其中各构件的选择应使每个构件的输出空间与下一个构件的输入空间匹配。不同构件可以利用不同选择的对称群 $\mathfrak{G}$。

[30]可以在网格、图、流形和群上定义有意义的度量；集合是一个显著例外，因为它没有预先定义的度量概念。

[31] “感受野”一词源于神经科学文献，指影响给定神经元输出的空间区域。

几何深度学习的不同设定 需要区分两种重要设定：一是假定定义域 Ω 固定，只关注定义在该域上的不同输入信号；二是定义域作为输入的一部分，与其上的信号一起变化。前者的经典例子出现在计算机视觉应用中：假定图像定义在固定定义域（网格）上。图分类是后者的例子，图的结构及其上定义的信号（例如节点特征）都很重要。在定义域可变时，几何稳定性（对 Ω 的形变不敏感）在几何深度学习架构中起关键作用。

该蓝图的普遍程度恰当，可用于广泛的几何定义域。不同的几何深度学习方法因此在定义域、对称群和上述构件的具体实现方面有所不同。正如后文所示，当前使用的大量深度学习架构都属于这一方案，因而可以从共同的几何原理推导出来。

下文第 4.1–4.6 节将以“五个 G”为重点描述各种几何定义域，第 5.1–5.8 节将介绍几何深度学习在这些定义域上的具体实现。

架构	定义域 Ω	对称群 $\mathfrak{G}$
CNN	网格	平移
球面 CNN	球面 / $SO(3)$	旋转 $SO(3)$
内禀 / 网格 CNN	流形	等距 $\mathrm{Iso}(\Omega)$ / 规范对称性 $SO(2)$
GNN	图	置换 Σ_n
Deep Sets	集合	置换 Σ_n
Transformer	完全图	置换 Σ_n
LSTM	一维网格	时间规整

第四章　几何定义域：五个 G

本文主要关注图（graphs）、网格（grids）、群（groups）、测地线（geodesics）和规范（gauges）。在这里，“群”指齐性空间中的全局对称变换，“测地线”指流形上的度量结构，而“规范”指在切丛（更一般地，在向量丛）上定义的局部参考标架。这些概念将在后文更详细地解释。在接下来的各节中，我们将详细讨论这些结构的主要共同要素与关键区别，并描述与它们相关的对称群。我们的叙述顺序并非按照一般性排列——事实上，网格是图的特例——而是为了突出支撑几何深度学习蓝图的重要概念。

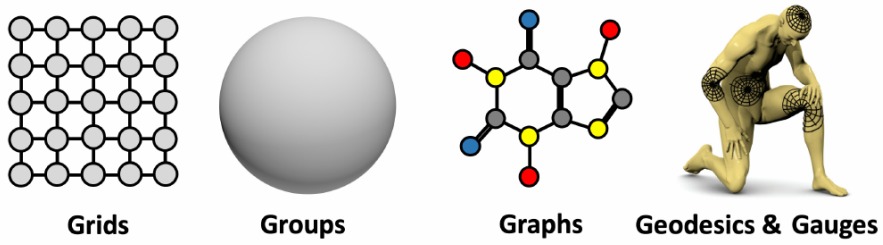


图 9: 几何深度学习的五个 G：网格，具有全局对称性的群与齐性空间，图，流形上的测地线与度量，以及规范（切空间或特征空间的标架）。

4.1　图与集合

从社会学到粒子物理，科学的许多分支都用图来模拟关系和相互作用系统。从我们的角度看，图产生了一种由置换群刻画的非常基本的不变性。此外，我们关注的其他对象，如网格和集合，都可以作为图的特例得到。

图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 由节点集合 $\mathcal{V}$ 和节点对之间的边集合 $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ 构成。[1]为了下文讨论，我们还假定每个节点 $u \in \mathcal{V}$ 都带有一个 s 维节点特征，记为 $\mathbf{x}_u$。社交网络可能是研究最多的图的例子之一：节点代表用户，边对应用户之间的好友关系，节点特征则对年龄、个人头像等用户属性建模。通常还可以给边或整个图赋予特征；但由于这不会改变本节的主要结论，我们将这一讨论留待未来工作。



同构是两个图之间保持边的双射。这里展示的两个同构图除节点重新排序外完全相同。

图的关键结构性质是：通常不假定 $\mathcal{V}$ 中的节点按任何特定次序给出，因此对图执行的操作都不应依赖节点排序。作用于图的函数所应满足的理想性质是置换不变性，它意味着对任意两个同构图，这些函数的结果相同。我们可以将其视为蓝图的一种特殊情形：定义域 $\Omega = \mathcal{G}$，空间 $\mathcal{X}(\mathcal{G}, \mathbb{R}^d)$ 是 d 维逐节点信号的空间。我们考虑的对称性由置换群 $\mathfrak{G} = \Sigma_n$ 给出，其元素是节点指标集合 $\{1, \dots, n\}$ 的所有可能排序。

先在集合上说明置换不变性的概念；集合是没有边的特殊图（即 $\mathcal{E} = \varnothing$）。将节点特征按行堆叠成 $n \times d$ 矩阵 $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)^\top$，实际上就指定了节点顺序。置换 $\mathfrak{g} \in \Sigma_n$ 对节点集合的作用相当于重排 $\mathbf{X}$ 的行，可以用 $n \times n$ 置换矩阵 $\rho(\mathfrak{g}) = P$ 表示，其中每行每列恰好有一个 1，其余元素均为零。[2]

若集合函数 f 对任意置换矩阵 P 满足 $f(P\mathbf{X}) = f(\mathbf{X})$，则称其为置换不变的。一个简单例子是

$$f(\mathbf{X}) = \phi\left(\sum_{u \in \mathcal{V}} \psi(\mathbf{x}_u)\right), \tag{6}$$

其中函数 ψ 独立作用于每个节点的特征，ϕ 作用于其输出求和聚合后的结果：由于求和与输入次序无关，这种函数对节点集合的置换不变，因此无论

[1]视应用领域而定，节点也称为顶点，边也常称为链接或关系。我们将交替使用这些术语。

[2]此类置换恰好有 $n!$ 个，因此即便 n 不大，Σ_n 也是一个很大的群。

如何置换节点，都保证返回相同输出。

上述函数给出“全局”的图级输出，但我们经常关心以逐节点方式“局部”作用的函数。例如，我们可能希望应用某个函数来更新每个节点的特征，得到一组潜在节点特征。若将这些潜在特征堆叠成矩阵 $\mathbf{H} = \mathbf{F}(\mathbf{X})$，它就不再是置换不变的：$\mathbf{H}$ 的行顺序应与 $\mathbf{X}$ 的行顺序绑定，以便知道哪个输出节点特征对应哪个输入节点。[3]我们需要更细致的置换等变性：一旦对输入选定某个置换，它就以一致的方式置换所得对象。形式上，如果对任意置换矩阵 P 都有 $\mathbf{F}(P\mathbf{X}) = P\mathbf{F}(\mathbf{X})$，则称 $\mathbf{F}(\mathbf{X})$ 为置换等变函数。共享的逐节点线性变换

$$\mathbf{F}_\Theta(\mathbf{X}) = \mathbf{X}\Theta \tag{7}$$

由权重矩阵 $\Theta \in \mathbb{R}^{d\times d'}$ 指定，是这种置换等变函数的一种可能构造；在本例中它产生形式为 $\mathbf{h}_u = \Theta^\top \mathbf{x}_u$ 的潜在特征。

这一构造自然来自几何深度学习蓝图。我们可以先尝试刻画线性等变映射（形式为 $FP\mathbf{X} = PF\mathbf{X}$ 的函数）；容易验证，任何此类映射都可以写成两个生成元的线性组合：恒等映射 $F_1\mathbf{X} = \mathbf{X}$ 和平均 $F_2\mathbf{X} = \frac{1}{n}\mathbf{1}\mathbf{1}^\top\mathbf{X} = \frac{1}{n}\sum_{u=1}^{n}\mathbf{x}_u$。如第 5.4 节将介绍的，广泛使用的 Deep Sets（Zaheer et al.，2017）架构恰好遵循这一蓝图。

现在可以将置换不变性与等变性从集合推广到图。一般情形 $\mathcal{E} \neq \varnothing$ 中，图的连接关系可以用 $n \times n$ 邻接矩阵 A 表示，定义为[4]

$$a_{uv} = \begin{cases} 1, & (u,v) \in \mathcal{E}, \\ 0, & \text{其他情况。} \end{cases} \tag{8}$$

注意，邻接矩阵与特征矩阵 A 和 $\mathbf{X}$ 是“同步”的：a_{uv} 指定由 $\mathbf{X}$ 第 u 行和第 v 行描述的节点之间的邻接信息。因此，对节点特征 $\mathbf{X}$ 应用置换矩阵 P，自动意味着将其应用于 A 的行和列，得到 $PAP^\top$。[5]若对任意置换矩阵 P，

[3]函数 $\mathbf{F}(\mathbf{X})$ 使用粗体，是为了强调它输出逐节点向量特征，因而是矩阵值函数。

[4]当图无向，即 $(u,v) \in \mathcal{E}$ 当且仅当 $(v,u) \in \mathcal{E}$ 时，邻接矩阵是对称的：$A = A^\top$。

[5]$PAP^\top$ 是 Σ_n 作用于矩阵的表示。

图级函数 f 满足[6]

$$f(P\mathbf{X}, PAP^\top) = f(\mathbf{X}, A), \tag{9}$$

则称其为置换不变的；若逐节点函数 $\mathbf{F}$ 满足

$$\mathbf{F}(P\mathbf{X}, PAP^\top) = P\mathbf{F}(\mathbf{X}, A), \tag{10}$$

则称其为置换等变的。

这里也可以先刻画线性等变函数。Maron et al.（2018）指出，任何满足式 (10) 的线性 $\mathbf{F}$ 都可以表示为 15 个线性生成元的线性组合；值得注意的是，这一生成元族与 n 无关。[7]在这些生成元中，我们的蓝图特别倡导同时具有局域性的生成元，即节点 u 的输出直接依赖于图中与其相邻的节点。通过定义何谓节点相邻，我们可以在模型构造中显式地形式化这一约束。

节点 u 的（无向）邻域，有时也称为一跳邻域，定义为[8]

$$\mathcal{N}_u = \{v : (u, v) \in \mathcal{E} \text{ 或 } (v, u) \in \mathcal{E}\}, \tag{11}$$

邻域特征定义为多重集

$$\mathbf{X}_{\mathcal{N}_u} = \{\{\mathbf{x}_v : v \in \mathcal{N}_u\}\}. \tag{12}$$

[9]对一跳邻域操作与蓝图的局域性方面相吻合：我们将图上的度量定义为使用 $\mathcal{E}$ 中边的节点间最短路径距离。

因此，GDL 蓝图给出构造图上置换等变函数的一般方法：指定一个作用于节点及其邻域特征的局部函数 $\phi(\mathbf{x}_u, \mathbf{X}_{\mathcal{N}_u})$，然后分别对每个节点的邻域

[6]为强调作用于图的函数现在需要考虑邻接信息，我们使用记号 $f(\mathbf{X}, A)$。

[7]这对应于贝尔数 B_4，它计数将四个元素分拆成若干部分的方式；此处四个元素由作用于邻接矩阵的线性映射的四个指标 $(u, v), (u', v')$ 给出。

[8]节点 u 本身经常也包含在自己的邻域内。

[9]多重集记为 $\{\{\cdots\}\}$，其中同一元素可以出现多次；在这里，不同节点的特征可能相同。

应用 ϕ，构造置换等变函数（见图 10）：

$$\mathbf{F}(\mathbf{X}, A) = \begin{bmatrix} \phi(\mathbf{x}_1, \mathbf{X}_{\mathcal{N}_1}) \\ \phi(\mathbf{x}_2, \mathbf{X}_{\mathcal{N}_2}) \\ \vdots \\ \phi(\mathbf{x}_n, \mathbf{X}_{\mathcal{N}_n}) \end{bmatrix}. \tag{13}$$

由于 $\mathbf{F}$ 通过对每个节点局部应用共享函数 ϕ 构造，其置换等变性依赖于 ϕ 的输出与 $\mathcal{N}_u$ 中节点的顺序无关。因此，如果将 ϕ 构造为置换不变的，这一性质便得到满足。正如未来工作将展示的，ϕ 的选择对这一方案的表达能力至关重要。当 ϕ 是单射时，它等价于 Weisfeiler–Lehman 图同构测试的一步；该测试是图论中的经典算法，通过迭代颜色细化为两个图同构提供必要条件。

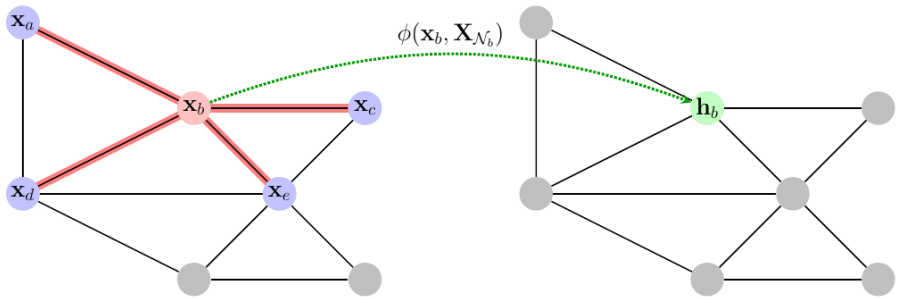


图 10: 通过将置换不变函数 ϕ 应用于每个邻域，构造图上置换等变函数的示意。在这里，ϕ 作用于节点 b 的特征 $\mathbf{x}_b$ 以及其邻域特征的多重集 $\mathbf{X}_{\mathcal{N}_b} = \{\{\mathbf{x}_a, \mathbf{x}_b, \mathbf{x}_c, \mathbf{x}_d, \mathbf{x}_e\}\}$。以此方式将 ϕ 应用于每个节点的邻域，就得到潜在特征矩阵 $\mathbf{H} = \mathbf{F}(\mathbf{X}, A)$ 的各行。

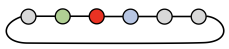
还值得注意的是，在这个例子中，定义在集合上的函数与定义在更一般的图上的函数之间的区别，是后者需要显式考虑定义域结构。因此，图有一个特殊之处：在机器学习问题中，定义域成为输入的一部分；而处理集合和网格（都是图的特例）时，我们可以只指定特征，并假定定义域固定。这一区别将反复出现在我们的讨论中。因而，在大多数图学习问题中，几何稳定性（对定义域形变的不变性）的概念至关重要。从上述构造直接可得，置换

不变和置换等变函数在同构（拓扑等价）的图上产生相同输出。这些结果可推广到近似同构的图，并已有若干关于图扰动下稳定性的结果（Levie et al., 2018）。我们将在讨论流形时回到这一重要问题，借助流形进一步研究这种不变性。

其次，由于具有额外结构，图和网格不同于集合，可以作非平凡粗化，从而产生多种池化操作。[10]

4.2 网格与欧几里得空间

我们考虑的第二类对象是网格。可以说，深度学习对计算机视觉、自然语言处理和语音识别的影响尤其显著。这些应用共有一个几何上的共同点：底层网格结构。如前所述，网格是具有特殊邻接关系的图的特例。然而，由于网格中节点的顺序固定，处理网格上信号的机器学习模型不再需要考虑置换不变性，而具有更强的几何先验：平移不变性。



具有周期边界条件的一维网格可视为首尾相接的环图。

循环矩阵与卷积 让我们更详细地讨论这一点。为简单起见，假设周期边界条件，我们可以将一维网格视为环图，其节点指标为 $0, 1, \ldots, n-1$，按模 n 计算（为简化记号，后文省略模运算），邻接矩阵的元素 $a_{u,u+1 \bmod n} = 1$，其余元素为零。与前面讨论的一般图相比，有两个主要区别。首先，每个节点 u 都具有相同的连接关系，即与邻居 $u-1$ 和 $u+1$ 相连，因而从结构上彼此不可区分。[11]其次，更重要的是，由于网格节点有固定顺序，邻居也有固定顺序：我们可以称 $u-1$ 为 “左邻居”，$u+1$ 为 “右邻居”。如果使用前面通过局部聚合函数 ϕ 设计等变函数 $\mathbf{F}$ 的方法，那么在网格的每个节点都有 $f(x_u) = \phi(x_{u-1}, x_u, x_{u+1})$：$\phi$ 不再需要置换不变。对于特定的线性变换

[10]更确切地说，仅假定集合结构时，我们无法定义非平凡粗化。已有方法可以从无序集合中推断拓扑结构，而这些结构可以允许非平凡粗化。

[11]如下文所示，这使网格成为齐性空间。

$\phi(x_{u-1}, x_u, x_{u+1}) = \theta_{-1}x_{u-1} + \theta_0 x_u + \theta_1 x_{u+1}$，可以将 $\mathbf{F}(\mathbf{X})$ 写为矩阵乘积：

$$\mathbf{F}(\mathbf{X}) = \begin{bmatrix} \theta_0 & \theta_1 & & & \theta_{-1} \\ \theta_{-1} & \theta_0 & \theta_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \theta_{-1} & \theta_0 & \theta_1 \\ \theta_1 & & & \theta_{-1} & \theta_0 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{n-2} \\ x_{n-1} \end{bmatrix}.$$

注意这一非常特殊的多对角结构：每条对角线上都重复同一个元素，在机器学习文献中有时称为“权重共享”。

更一般地，给定向量 $\theta = (\theta_0, \ldots, \theta_{n-1})$，将 θ 循环平移后的各版本依次排列，得到循环矩阵 $C(\theta) = (\theta_{u-v \bmod n})$。循环矩阵与离散卷积是同义的：[12]

$$(x \star \theta)_u = \sum_{v=0}^{n-1} x_{v \bmod n} \theta_{u-v \bmod n},$$

因为 $C(\theta)x = x \star \theta$。特取 $\theta = (0, 1, 0, \ldots, 0)^\top$，得到一个特殊循环矩阵，它将向量向右平移一个位置。这个矩阵称为（右）平移或平移算子，记作 S。[13]

循环矩阵可以通过交换性质来刻画：循环矩阵的乘法可交换，即对任意 θ 和 η，有 $C(\theta)C(\eta) = C(\eta)C(\theta)$。由于平移也是循环矩阵，我们得到熟悉的卷积算子的平移等变性：

$$SC(\theta)x = C(\theta)Sx.$$

这种交换性质并不奇怪，因为底层对称群（平移群）是阿贝尔群。此外，反方向也成立：矩阵是循环矩阵，当且仅当它与平移交换。这进而允许我们将卷积定义为平移等变的线性操作，也很好地说明了几何先验的力量以及几何机器学习的整体哲学：卷积从平移对称性的第一性原理中产生。

注意，与集合和图的情形不同，线性无关的平移等变函数（卷积）的数量随定义域大小增长，因为循环矩阵的每条对角线都有一个自由度。然而，

[12] 由于周期边界条件，这里是循环卷积。在信号处理中，θ 通常称为“滤波器”；在 CNN 中，其系数是可学习的。

[13] 左平移算子为 $S^\top$。显然，先左移再右移（或反之）没有效果，即 S 是正交的：$S^\top S = SS^\top = I$。

尺度分离先验保证滤波器可以是局域的，从而使每层的参数复杂度同样为 $\Theta(1)$。我们将在第 5.1 节讨论利用这些原理实现卷积神经网络架构时验证这一点。

离散傅里叶变换的推导 我们已经提到傅里叶变换及其与卷积的联系：傅里叶变换将卷积操作对角化，这一重要性质用于信号处理，使得可以在频域中通过傅里叶变换的逐元素乘积来执行卷积。然而，教材通常只陈述这一事实，很少解释傅里叶变换从何而来、傅里叶基有何特殊之处。这里我们可以展示其由来，再次说明对称性的基本原理有多么根本。

为此，回忆线性代数中的一个事实：（可对角化的）矩阵当且仅当两两交换时可同时对角化。[14]换言之，所有循环矩阵存在一个共同的特征基，它们在该基下仅以特征值不同。因此，我们可以选择一个循环矩阵计算其特征向量——这些向量也必然是其他所有循环矩阵的特征向量。选择平移算子很方便，其特征向量恰好是离散傅里叶基：[15]

$$\phi_k = \frac{1}{\sqrt{n}} \left(1, e^{\frac{2\pi i k}{n}}, e^{\frac{4\pi i k}{n}}, \dots, e^{\frac{2\pi i (n-1) k}{n}}\right)^\top, \qquad k = 0, 1, \dots, n-1,$$

可以将它们排列为 $n \times n$ 傅里叶矩阵 $\Phi = (\phi_0, \dots, \phi_{n-1})$。左乘 Φ^* 得到离散傅里叶变换（DFT），左乘 Φ 得到逆 DFT：[16]

$$\widehat{x}_k = \frac{1}{\sqrt{n}} \sum_{u=0}^{n-1} x_u e^{-\frac{2\pi i k u}{n}}, \qquad x_u = \frac{1}{\sqrt{n}} \sum_{k=0}^{n-1} \widehat{x}_k e^{+\frac{2\pi i k u}{n}}.$$

由于所有循环矩阵可同时对角化，它们也都被傅里叶变换对角化，且仅以特征值不同。循环矩阵 $C(\theta)$ 的特征值是滤波器的傅里叶变换（例如

[14]我们还必须假定特征值各不相同，否则可能有多种对角化方式。对于这里选择的 S，这一假设成立。

[15]S 是正交但非对称的，因此其特征向量正交，而特征值是复数（单位根）。

[16]注意特征向量是复数，因此转置 Φ 时需要取复共轭。

Bamieh（2018））$\widehat{\theta} = \Phi^* \theta$，因此得到卷积定理：[17]

$$C(\theta)x = \Phi \begin{bmatrix} \widehat{\theta}_0 & & \\ & \ddots & \\ & & \widehat{\theta}_{n-1} \end{bmatrix} \Phi^* x = \Phi(\widehat{\theta}\,\widehat{x}).$$

由于傅里叶矩阵 Φ 具有特殊的代数结构，可以使用快速傅里叶变换（FFT）算法，以 $O(n \log n)$ 的复杂度计算乘积 $\Phi^* x$ 和 Φx。这是频域滤波在信号处理中广受欢迎的原因之一；此外，滤波器通常直接在频域中设计，因此无需显式计算傅里叶变换 $\widehat{\theta}$。

除了上述傅里叶变换和卷积推导的教学价值，它还提供了将这些概念推广到图的方案。认识到环图的邻接矩阵恰好是平移算子后，就可以通过计算邻接矩阵的特征向量，发展图傅里叶变换和卷积算子的类比（例如 Sandryhaila and Moura（2013））。早期通过类比 CNN 发展图神经网络的尝试有时称为“谱 GNN”，正是利用了这一蓝图。我们将在第 4.4–4.6 节看到，这一类比有一些重要局限。[18]第一个局限来自网格是固定的，其上所有信号都可在同一个傅里叶基下表示。相比之下，一般图上的傅里叶基依赖于图的结构，因此无法直接比较两个不同图上的傅里叶变换；这在机器学习问题中表现为缺乏泛化能力。其次，由一维网格张量积构成的多维网格保留了底层结构：傅里叶基元素和相应频率（特征值）可按多个维度组织。例如，对于图像，可以自然地讨论水平和垂直频率，滤波器也有方向概念。在图上，傅里叶域的结构是一维的，因为只能按照相应频率的大小组织傅里叶基函数。因此，图滤波器不区分方向，即为各向同性。

连续傅里叶变换的推导 为完整起见，也为引出接下来的讨论，我们在连续情形中重复上述分析。如第 3.4 节，考虑定义在 $\Omega = \mathbb{R}$ 上的函数和平移算子 $(S_v f)(u) = f(u - v)$，它将 f 平移位置 v。对傅里叶基函数 $\phi_\xi(u) = e^{i\xi u}$

[17]由于傅里叶变换是正交矩阵（$\Phi^*\Phi = I$），从几何上看它相当于坐标系变换，即 n 维旋转。在这一坐标系（“傅里叶域”）中，循环矩阵 C 的作用变成逐元素乘积。

[18]图信号处理中，常以图拉普拉斯算子的特征向量代替邻接矩阵来构造图傅里叶变换，见 Shuman et al.（2013）。在网格上，两种矩阵具有共同特征向量；但在图上，它们给出有所不同、尽管相关的构造。

应用 S_v，由指数的结合性得到

$$S_v e^{i\xi u} = e^{i\xi(u-v)} = e^{-i\xi v} e^{i\xi u},$$

即 $\phi_\xi^u(u)$ 是 S_v 的复特征向量，相应复特征值为 $e^{-i\xi v}$，与离散情形完全对应。由于 S_v 是酉算子（即对任意 p 和 $x \in L^p(\mathbb{R})$，有 $\|S_v x\|_p = \|x\|_p$），任意特征值 λ 必须满足 $|\lambda| = 1$，这恰好对应上面得到的特征值 $e^{-i\xi v}$。此外，平移算子的谱是单的，意味着具有相同特征值的两个函数必然共线。事实上，假设对某个 ξ_0 有 $S_v f = e^{-i\xi_0 v} f$，两边作傅里叶变换得到

$$\forall \xi, \quad e^{-i\xi v} \widehat{f}(\xi) = e^{-i\xi_0 v} \widehat{f}(\xi),$$

这意味着对 $\xi \neq \xi_0$ 有 $\widehat{f}(\xi) = 0$，于是 $f = \alpha \phi_{\xi_0}$。

对于一般的平移等变线性算子 C（$S_v C = C S_v$），有

$$S_v C e^{i\xi u} = C S_v e^{i\xi u} = e^{-i\xi v} C e^{i\xi u},$$

这意味着 $Ce^{i\xi u}$ 也是 S_v 的特征函数，相应特征值为 $e^{-i\xi v}$；由谱的单性可得 $Ce^{i\xi u} = \beta \phi_\xi(u)$。[19]换言之，傅里叶基是所有平移等变算子的特征基。因此，C 在傅里叶域中为对角形式，可以写为 $Ce^{i\xi u} = \widehat{p}_C(\xi) e^{i\xi u}$，其中 $\widehat{p}_C(\xi)$ 是作用于不同频率 ξ 的传递函数。最后，对任意函数 $x(u)$，由线性性可得

$$\begin{aligned}(Cx)(u) &= C \int_{-\infty}^{+\infty} \widehat{x}(\xi) e^{i\xi u}\, d\xi = \int_{-\infty}^{+\infty} \widehat{x}(\xi) \widehat{p}_C(\xi) e^{i\xi u}\, d\xi \\ &= \int_{-\infty}^{+\infty} p_C(v) x(u-v)\, dv = (x \star p_C)(u),\end{aligned}$$

其中 $p_C(u)$ 是 $\widehat{p}_C(\xi)$ 的逆傅里叶变换。由此可得，每个线性平移等变算子都是卷积。[20]

4.3 群与齐性空间

对网格的讨论突出了平移与卷积之间的密切联系：卷积是线性平移等变操作；反过来，任何平移等变线性算子都是卷积。此外，平移算子可以被傅

[19] “特征函数”与“特征向量”同义，用于指连续算子的特征向量。

[20] 平移群的谱刻画是泛函分析中更一般结果——Stone 定理——的一个特例；该定理对任何单参数酉群给出等价刻画。

里叶变换同时对角化。事实表明，这只是一个大得多的故事的一部分：卷积和傅里叶变换都可以对任何能够求和或积分的对称群定义。[21]

考虑欧几里得定义域 $\Omega = \mathbb{R}$。我们可以将卷积理解为模式匹配操作：用滤波器 $\theta(u)$ 的平移副本与输入信号 $x(u)$ 匹配。卷积 $(x \star \theta)(u)$ 在点 u 的值是信号与平移 u 后的滤波器的内积：[22]

$$(x \star \theta)(u) = \langle x, S_u \theta \rangle = \int_{\mathbb{R}} x(v)\theta(u+v)\, dv.$$

注意，此处 u 既是定义域 $\Omega = \mathbb{R}$ 上的点，也是平移群的元素；我们可以将平移群与定义域本身等同，即 $\mathfrak{G} = \mathbb{R}$。现在我们将说明如何推广这一构造：只需将平移群换为作用于 Ω 的另一个群 $\mathfrak{G}$。

群卷积 如第 3 章所述，群 $\mathfrak{G}$ 在定义域 Ω 上的作用，通过 $\rho(\mathfrak{g})x(u) = x(\mathfrak{g}^{-1}u)$ 在信号空间 $\mathcal{X}(\Omega)$ 上诱导出 $\mathfrak{G}$ 的表示 ρ。在上述例子中，$\mathfrak{G}$ 是平移群，其元素通过 $u + v$ 平移坐标；而 $\rho(\mathfrak{g})$ 是作用于信号的平移算子 $(S_v x)(u) = x(u - v)$。最后，为将滤波器应用于信号，我们利用 $\mathcal{X}(\Omega)$ 是希尔伯特空间这一假设，其内积为

$$\langle x, \theta \rangle = \int_{\Omega} x(u)\theta(u)\, du,$$

这里为简单起见假定信号为标量值，即 $\mathcal{X}(\Omega, \mathbb{R})$；一般情况下内积具有式 (2) 的形式。[23]

既然定义了如何变换信号并将其与滤波器匹配，我们便可为 Ω 上的信号定义群卷积：

$$(x \star \theta)(\mathfrak{g}) = \langle x, \rho(\mathfrak{g})\theta \rangle = \int_{\Omega} x(u)\theta(\mathfrak{g}^{-1}u)\, du. \tag{14}$$

[21] 严格地说，我们需要群是局部紧的，以便存在左不变 Haar 测度。对该测度积分时，可以用任何群元素 “平移” 被积函数而得到相同结果，正如对函数 $x : \mathbb{R} \to \mathbb{R}$ 有 $\int_{-\infty}^{+\infty} x(u)\, du = \int_{-\infty}^{+\infty} x(u - v)\, du$。

[22] 注意这里定义的并非卷积，而是互相关；深度学习通常默认以 “卷积” 之名称呼它。为与下文一致，我们如此定义，因为按我们的记号，$(\rho(\mathfrak{g})x)(u) = x(u - v)$，而 $(\rho(\mathfrak{g}^{-1})x)(u) = x(u + v)$。

[23] 积分是关于 Ω 上不变测度 μ 进行的。当 μ 离散时，这意味着在 Ω 上求和。

注意，$x \star \theta$ 的取值对应于群 $\mathfrak{G}$ 的元素 $\mathfrak{g}$，而不是定义域 Ω 上的点。因此，以下一层将 $x \star \theta$ 作为输入时，它应作用于定义在群 $\mathfrak{G}$ 上的信号；我们很快会回到这一点。

正如传统欧几里得卷积具有平移等变性，更一般的群卷积也具有 $\mathfrak{G}$-等变性。关键观察是：将信号 x 与经 $\mathfrak{g}$ 变换的滤波器 $\rho(\mathfrak{g})\theta$ 匹配，等同于将逆变换后的信号 $\rho(\mathfrak{g}^{-1})x$ 与未变换的滤波器 θ 匹配。数学上可表示为 $\langle x, \rho(\mathfrak{g})\theta \rangle = \langle \rho(\mathfrak{g}^{-1})x, \theta \rangle$。由此，式 (14) 的 $\mathfrak{G}$-等变性直接来自其定义及群表示的定义性质 $\rho(\mathfrak{h}^{-1})\rho(\mathfrak{g}) = \rho(\mathfrak{h}^{-1}\mathfrak{g})$：

$$\begin{aligned}(\rho(\mathfrak{h})x \star \theta)(\mathfrak{g}) &= \langle \rho(\mathfrak{h})x, \rho(\mathfrak{g})\theta \rangle = \langle x, \rho(\mathfrak{h}^{-1}\mathfrak{g})\theta \rangle \\ &= \rho(\mathfrak{h})(x \star \theta)(\mathfrak{g}).\end{aligned}$$

来看一些例子。上文研究的一维网格情形对应 $\Omega = \mathbb{Z}_n = \{0, \dots, n-1\}$ 和循环平移群 $\mathfrak{G} = \mathbb{Z}_n$。此时群元素是指标的循环平移，即元素 $\mathfrak{g} \in \mathfrak{G}$ 可以与某个 $u = 0, \dots, n-1$ 等同，使得 $\mathfrak{g}.v = v - u \bmod n$，而逆元素满足 $\mathfrak{g}^{-1}.v = v + u \bmod n$。重要的是，在此例中群元素（平移）也是定义域的元素（指标）。因此，稍微滥用记号可以将这两个结构等同，即 $\Omega = \mathfrak{G}$；此时群卷积表达式

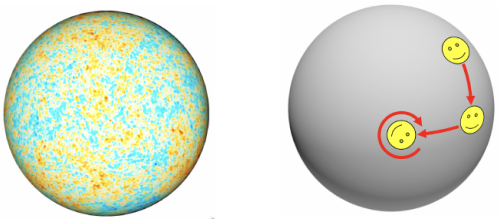
$$(x \star \theta)(\mathfrak{g}) = \sum_{v=0}^{n-1} x_v \theta_{\mathfrak{g}^{-1}v}$$

给出熟悉的卷积 $(x \star \theta)_u = \sum_{v=0}^{n-1} x_v \theta_{v+u \bmod n}$。[24]

球面卷积 现在考虑二维球面 $\Omega = S^2$ 及旋转群，即特殊正交群 $\mathfrak{G} = SO(3)$。虽然选择此例是出于教学目的，它实际上非常实用，出现在众多应用中。例如，在天体物理中，观测数据通常自然具有球面几何。此外，在化学应用中对分子建模并试图预测其性质（例如为了虚拟药物筛选）时，球面对称性也十分重要。

将球面上的点表示为三维单位向量 $\mathbf{u}$，满足 $\|\mathbf{u}\| = 1$，则群的作用可以表示为满足 $\det(R) = 1$ 的 3×3 正交矩阵 R。因此，球面卷积可以写为信

[24]事实上，这里仍然是互相关。



左：普朗克空间天文台捕获的宇宙微波背景辐射，是 S^2 上的信号。右：$SO(3)$ 群在 S^2 上的作用。注意有三类可能的旋转；$SO(3)$ 是三维流形。

号与旋转后的滤波器之间的内积：

$$(x \star \theta)(R) = \int_{S^2} x(\mathbf{u})\theta(R^{-1}\mathbf{u})\, d\mathbf{u}.$$

首先应注意，现在群不再与定义域相同：群 $SO(3)$ 是李群，实际上是三维流形，而 S^2 是二维流形。因此，与前一例不同，此时卷积是 $SO(3)$ 而非 Ω 上的函数。

这在实践中有重要后果：在几何深度学习蓝图中，我们通过将后续算子作用于前一算子的输出来串接多个等变映射（深度学习术语中的“层”）。对于平移，可以连续应用多个卷积，因为它们的输出都定义在同一个域 Ω 上。在一般情形中，由于 $x \star \theta$ 是 $\mathfrak{G}$ 而不是 Ω 上的函数，无法在后续完全使用相同的操作——下一个操作必须处理 $\mathfrak{G}$ 上定义的信号，即 $x \in \mathcal{X}(\mathfrak{G})$。群卷积的定义允许这一情形：取定义域 $\Omega = \mathfrak{G}$，并让 $\mathfrak{G}$ 自身通过由其复合运算定义的群作用 $(\mathfrak{g}, \mathfrak{h}) \mapsto \mathfrak{g}\mathfrak{h}$ 作用于它。这得到作用于 $x \in \mathcal{X}(\mathfrak{G})$ 的表示 $\rho(\mathfrak{g})$：$(\rho(\mathfrak{g})x)(\mathfrak{h}) = x(\mathfrak{g}^{-1}\mathfrak{h})$。[25]同以前一样，内积通过对定义域上的信号与滤波器的逐点乘积积分定义，而现在定义域为 $\Omega = \mathfrak{G}$。在球面卷积的例子中，第二层卷积因而具有形式

$$((x \star \theta) \star \phi)(R) = \int_{SO(3)} (x \star \theta)(Q)\phi(R^{-1}Q)\, dQ.$$

由于卷积涉及内积，而内积又需要在定义域 Ω 上积分，我们只能在小的定义域（离散情形）或低维定义域（连续情形）上使用它。例如，可以在

[25] $\mathfrak{G}$ 作用于定义在 $\mathfrak{G}$ 自身上的函数的表示称为 $\mathfrak{G}$ 的正则表示。

平面 $\mathbb{R}^2$（二维）、特殊正交群 $SE(3)$（三维）或图的有限节点集合（n 维）上使用卷积，但实践中无法在有 $n!$ 个元素的置换群 Σ_n 上进行卷积。同样，在仿射群等更高维群上积分（包含平移、旋转、剪切和缩放，共六维）在实践中不可行。尽管如此，如我们在第 5.3 节所见，仍可通过处理定义在大群 $\mathfrak{G}$ 所作用的低维空间 Ω 上的信号，为该群构造等变卷积。事实上，可以证明，两个定义域 Ω, Ω' 之间任意等变线性映射 $f : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega')$ 都可以写成类似这里讨论的群卷积的广义卷积。

其次，我们注意到，上一节由卷积的平移等变性推导出的傅里叶变换，也可通过将信号投影到对称群不可约表示的矩阵元上，推广到更一般的情形。我们将在未来的工作中讨论。对于这里研究的 $SO(3)$，这会产生球谐函数和 Wigner D 函数，它们在量子力学和化学中应用广泛。

最后，指出本节讨论迄今所依赖的假设：无论 Ω 是网格、平面还是球面，我们都可以将每个点变换到任何其他点；直观地说，定义域上所有点“看起来一样”。具有这一性质的定义域 Ω 称为齐性空间，即对任意 $u, v \in \Omega$，存在 $\mathfrak{g} \in \mathfrak{G}$ 使 $\mathfrak{g}.u = v$。[26]下一节将尝试放宽这一假设。

4.4 测地线与流形

在上一个例子中，球面 S^2 是一个流形，但它比较特殊：由于其齐性结构，它具有全局对称群。[27]遗憾的是，大多数流形通常并不具有全局对称性。在这种情况下，我们无法直接定义 $\mathfrak{G}$ 在 Ω 的信号空间上的作用，也就不能利用它“滑动”滤波器，将卷积定义为经典构造的直接推广。尽管如此，流形确实有两类不变性，我们将在本节研究：保持度量结构的变换，以及局部参考标架的变化。

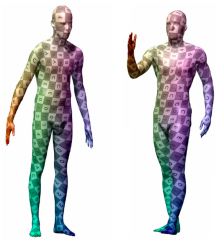
对许多机器学习读者来说，流形或许显得有些陌生，但它们实际上在各种科学领域中十分常见。在物理学中，流形作为宇宙的模型发挥核心作用——根据爱因斯坦的广义相对论，引力源于时空的曲率，而时空被建模为伪黎曼流形。在计算机图形学和视觉等更“平常”的领域，流形是三维形状的

[26]这里还默认 $\mathfrak{e}.u = u$ 和 $\mathfrak{g}(\mathfrak{h}.u) = (\mathfrak{g}\mathfrak{h}).u$。

[27]旋转群 $SO(3)$ 也是流形，因为它是李群。

常见数学模型。[28]这些模型的应用范围很广，从虚拟现实、增强现实以及通过“动作捕捉”获得的特效，到研究蛋白质相互作用的结构生物学：蛋白质像三维拼图的碎片一样粘在一起（化学术语称为“结合”）。这些应用的共同点是用流形表示某个三维对象的边界曲面。

此类模型方便的原因有几个。首先，它们为三维对象提供紧凑描述，不必像基于网格的表示那样为空间中的“空处”分配内存。其次，它们允许忽略对象的内部结构。例如，在结构生物学中，蛋白质分子的内部折叠往往与发生在分子表面的相互作用无关，这一点便很有用。第三，也是最重要的一点，我们经常需要处理发生非刚性形变的可变形对象。人体就是一个例子；计算机图形学和视觉中的许多应用，例如前述动作捕捉和虚拟化身，都要求形变不变性。这类形变可以很好地建模为保持（黎曼）流形内禀结构的变换，即保持沿流形测量的点间距离，而不考虑流形如何嵌入周围空间。



人体是一个以近似等距方式发生形变的非刚性对象的例子。

应当强调，在几何深度学习蓝图中，流形属于定义域可变的情形，在这一意义上与图类似。我们将突出对定义域形变不变性的概念的重要性——即第 3.3 节所称的“几何稳定性”。由于机器学习读者可能对微分几何不太熟悉，我们将介绍讨论所需的基本概念，并请读者参阅 Penrose（2005）了解详细阐述。

黎曼流形 由于流形的形式定义较为复杂，我们宁愿牺牲一些精确性来给出直观图像。在这里，可以将（可微或光滑）流形看作一个局部欧几里得的光滑多维曲面：每个点周围任意小的邻域都可以形变为 $\mathbb{R}^s$ 的邻域；此时称该

[28] “三维”一词有些误导，它指的是嵌入空间；形状本身是二维流形（曲面）。

流形为 s 维的。[29]这允许我们通过切空间 $T_u\Omega$ 局部近似点 u 附近的流形。可以想象一个典型二维流形——球面——并在一点上附着一个平面，来理解切空间：当放大程度足够时，球面看起来就是平面的（图 11）。所有切空间的集合称为切丛，记为 $T\Omega$；我们将在第 4.5 节更详细地讨论丛的概念。[30]

切向量记作 $X \in T_u\Omega$，可以看作从点 u 出发的局部位移。为了测量切向量的长度及其夹角，需要给切空间赋予额外结构，表示为一个随 u 光滑变化的正定双线性函数 $g_u : T_u\Omega \times T_u\Omega \to \mathbb{R}$。这种函数称为黎曼度量，以 1856 年引入该概念的 Bernhardt Riemann 命名；它可以看作切空间上的内积 $\langle X, Y\rangle_u = g_u(X, Y)$，是任意两个切向量 $X, Y \in T_u\Omega$ 之间夹角的表达。度量还诱导范数 $\|X\|_u = g_u(X, X)^{1/2}$，允许在局部测量向量长度。[31]

必须强调，切向量是独立存在且与坐标无关的抽象几何实体。若要以数值数组表达切向量 X，只能将它表示为相对于某个局部基 $\{X_1, \dots, X_s\} \subseteq T_u\Omega$ 的坐标列表 $\mathbf{x} = (x_1, \dots, x_s)$。类似地，度量可在该基下表示为 $s \times s$ 矩阵 G，其元素为 $g_{ij} = g_u(X_i, X_j)$。我们将在第 4.5 节回到这一点。[32]

赋有度量的流形称为黎曼流形，而完全可以用度量表达的性质称为内禀的。这对我们的讨论至关重要：按照蓝图，我们将构造作用于定义在 Ω 上的信号的函数，使其对称为等距映射的保度量变换不变；等距映射会改变流形形状，但不影响其局部结构。如果这样的函数能用内禀量表达，就自动保证具有等距不变性，因而不受等距形变影响。这些结果还可以进一步扩展到近似等距的情形；这便是蓝图中所讨论的几何稳定性（定义域形变）的一个例子。

如前所述，黎曼流形的定义不要求在任何空间中有几何实现；但事实表明，任何光滑黎曼流形都可利用欧几里得空间的结构来诱导黎曼度量，从而实现为足够高维欧几里得空间的子集（此时称流形“嵌入”该空间）。[33]然

[29]这里“光滑”指可微充分多次，为方便起见默认如此；“形变”在此指微分同胚，即可以用光滑、可逆且逆映射也光滑的映射在两个邻域之间变换。

[30]形式上，切丛是不交并 $T\Omega = \bigsqcup_{u\in\Omega} T_u\Omega$。

[31]若对任意非零向量 $X \neq 0$ 都有 $g(X, X) > 0$，则称双线性函数 g 正定。若 g 表示为矩阵 G，这意味着 $G \succ 0$。行列式 $|G|^{1/2}$ 给出不依赖基选择的局部体积元。

[32]遗憾的是，向量过于频繁地被等同于其坐标。为强调这一重要区别，我们用 X 表示切向量，用 $\mathbf{x}$ 表示其坐标。

[33]这一结果称为嵌入定理，由 Nash（1956）提出。折纸艺术体现了平面曲面在 $\mathbb{R}^3$ 中的不

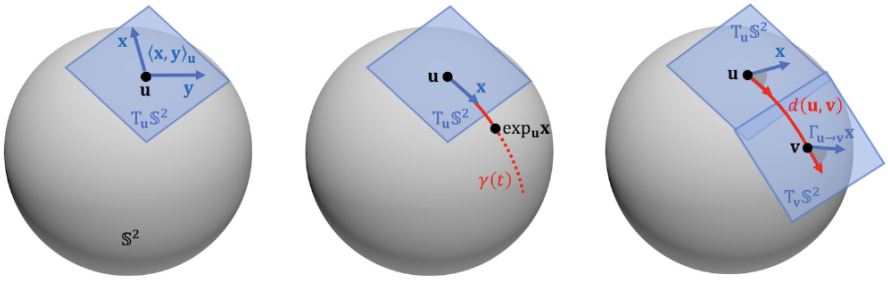


图 11: 以二维球面 $S^2 = \{\mathbf{u} \in \mathbb{R}^3 : \|\mathbf{u}\| = 1\}$ 为例说明黎曼几何的基本概念；该球面实现为 $\mathbb{R}^3$ 的子集（子流形）。球面的切空间为 $T_{\mathbf{u}}S^2 = \{\mathbf{x} \in \mathbb{R}^3 : \mathbf{x}^\top \mathbf{u} = 0\}$，是二维平面，因此这是二维流形。黎曼度量就是限制在切平面上的欧几里得内积：对任意 $\mathbf{x}, \mathbf{x} \in T_{\mathbf{u}}S^2$，有 $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{u}} = \mathbf{x}^\top \mathbf{y}$。指数映射为 $\exp_{\mathbf{u}}(\mathbf{x}) = \cos(\|\mathbf{x}\|)\mathbf{u} + \frac{\sin(\|\mathbf{x}\|)}{\|\mathbf{x}\|}\mathbf{x}$，其中 $\mathbf{x} \in T_{\mathbf{u}}S^2$。测地线是长度为 $d(\mathbf{u}, \mathbf{v}) = \cos^{-1}(\mathbf{u}^\top \mathbf{v})$ 的大圆弧。

而，这种嵌入不一定唯一：正如我们将看到的，同一黎曼度量可以有两种不同的等距实现。



平面曲面的不同等距嵌入示例。图片：Shutterstock/300 librarians。

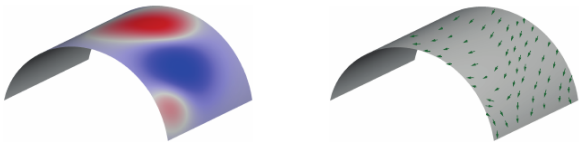
标量场与向量场 由于我们关心定义在 Ω 上的信号，需要为流形上的标量值和向量值函数给出适当概念。（光滑）标量场是形如 $x : \Omega \to \mathbb{R}$ 的函数。标量场构成向量空间 $\mathcal{X}(\Omega, \mathbb{R})$，可以赋以内积

$$\langle x, y \rangle = \int_\Omega x(u)y(u)\, du, \tag{15}$$

同等距嵌入（图片：Shutterstock/300 librarians）。

其中 du 是黎曼度量诱导的体积元。（光滑）切向量场是形如 $X : \Omega \to T\Omega$ 的函数，它将每个点映到相应切空间中的切向量，即 $u \mapsto X(u) \in T_u\Omega$。向量场也构成向量空间 $\mathcal{X}(\Omega, T\Omega)$，其内积通过黎曼度量定义为

$$\langle X, Y \rangle = \int_\Omega g_u(X(u), Y(u))\, du. \tag{16}$$



左：标量场示例。右：向量场示例。通常假定这些场与流形本身属于相同的正则性（光滑性）类别。

内禀梯度 理解（实际上也是定义）向量场的另一种方法，是把它看作广义的导数概念。在经典微积分中，可以通过微分 $dx(u) = x(u + du) - x(u)$ 将（光滑）函数局部线性化；微分给出在点 u 处由于无穷小位移 du 而导致的函数值变化。然而，在这里不能直接照搬该定义，因为流形缺少全局向量空间结构，形如“$u + du$”的表达没有意义。

解决办法是用切向量作为局部无穷小位移的模型。给定光滑标量场 $x \in \mathcal{X}(\Omega, \mathbb{R})$，可以将（光滑）向量场看作线性映射 $Y : \mathcal{X}(\Omega, \mathbb{R}) \to \mathcal{X}(\Omega, \mathbb{R})$，满足导子的性质：对任意常数 c，$Y(c) = 0$（对应常函数导数为零的直觉）；对任意光滑标量场 $x, z \in \mathcal{X}(\Omega, \mathbb{R})$，$Y(x + z) = Y(x) + Y(z)$（线性），且 $Y(xz) = Y(x)z + xY(z)$（乘积法则或 Leibniz 法则）。可以证明，可以用这些性质公理化地定义向量场。微分 $dx(Y) = Y(x)$ 可以视为算子 $(u, Y) \mapsto Y(x)$，并作如下解释：在点 u 处，位移 $Y \in T_u\Omega$ 导致的 x 的变化由 $d_u x(Y)$ 给出。它由此推广了经典的方向导数概念。[34]

另一种观点是，在每一点 u，微分可看作作用于切向量 $X \in T_u\Omega$ 的线性泛函 $dx_u : T_u\Omega \to \mathbb{R}$。向量空间上的线性泛函称为对偶向量或余向量；如

[34] 重要的是，这一构造完全没有使用黎曼度量，因而可以推广到第 4.5 节讨论的更一般的丛构造。

果另外给定内积（黎曼度量），则对偶向量总可以表示为[35]

$$dx_u(X) = g_u(\nabla x(u), X).$$

点 u 处微分的表示是切向量 $\nabla x(u) \in T_u\Omega$，称为 x 的（内禀）梯度；与经典微积分中的梯度类似，它可以看作 x 增长最快的方向。将梯度视为算子 $\nabla : \mathcal{X}(\Omega, \mathbb{R}) \to \mathcal{X}(\Omega, T\Omega)$，它在每一点指定 $x(u) \mapsto \nabla x(u) \in T_u\Omega$；因此，标量场 x 的梯度是向量场 ∇x。

测地线 现在考虑流形上一条光滑曲线 $\gamma : [0, T] \to \Omega$，其端点为 $u = \gamma(0)$ 和 $v = \gamma(T)$。曲线在 t 处的导数是切向量 $\gamma'(t) \in T_{\gamma(t)}\Omega$，称为速度向量。在连接 u, v 的所有曲线中，我们关心长度最短的曲线，即寻找使长度泛函最小的 γ：[36]

$$\ell(\gamma) = \int_0^T \|\gamma'(t)\|_{\gamma(t)}\, dt = \int_0^T g_{\gamma(t)}(\gamma'(t), \gamma'(t))^{1/2}\, dt.$$

这样的曲线称为测地线（来自希腊语 γεοδαισία，字面意思为“土地的划分”），在微分几何中发挥重要作用。对我们的讨论至关重要的是，上述定义测地线的方式是内禀的，因为它们（通过长度泛函）仅依赖黎曼度量。

熟悉微分几何的读者可能记得，测地线是一个更一般的概念，其定义实际上不一定需要黎曼度量，而需要联络。联络也称协变导数，因为它将导数概念推广到向量场和张量场；它与我们的微分构造类似，是公理化定义的。给定黎曼度量，存在唯一的特殊联络，称为 Levi–Civita 联络，在黎曼几何中通常默认使用。[37]由这一联络产生的测地线就是上面定义的长度最短曲线。

接下来将展示如何利用测地线定义流形上切向量的移动方式（平行移动）、建立流形到切空间的局部内禀映射（指数映射）以及定义距离（测地度量）。这样便可通过在切空间局部应用滤波器，构造类似卷积的操作。

平行移动 处理流形时我们已经遇到一个问题：不能直接将两点 $u, v \in \Omega$ 相加或相减。试图比较不同点处的切向量时也会出现同样问题：尽管它们维

[35]这是 Riesz–Fréchet 表示定理的结果：每个对偶向量都可以表达为与某个向量的内积。

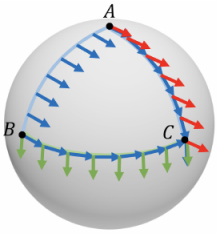
[36]这里默认曲线采用弧长参数化，使 $\|\gamma'\| = 1$（恒定速度）。

[37]Levi–Civita 联络无挠并与度量相容。黎曼几何基本定理保证其存在且唯一。

数相同，却属于不同的空间，例如 $X \in T_u\Omega$ 和 $Y \in T_v\Omega$，因此不能直接比较。测地线提供了将向量从一点移动到另一点的机制：设 γ 是连接 $u = \gamma(0)$ 与 $v = \gamma(T)$ 的测地线，且 $X \in T_u\Omega$。可以沿测地线定义一组新的切向量 $X(t) \in T_{\gamma(t)}\Omega$，使得 $X(t)$ 的长度及其与曲线速度向量之间的夹角（通过黎曼度量表示）保持不变：

$$g_{\gamma(t)}(X(t), \gamma'(t)) = g_u(X, \gamma'(0)) = \text{const},$$
$$\|X(t)\|_{\gamma(t)} = \|X\|_u = \text{const}.$$

于是，在终点 v 得到唯一向量 $X(T) \in T_v\Omega$。



在球面上，将向量从 A 欧几里得平移到 C 没有意义，因为所得向量（红色）不在切平面内。沿路径从 A 到 C 的平行移动（蓝色）使向量旋转。结果依赖路径：沿 BC 和 ABC 得到不同结果。

沿用上述记号，由 $\Gamma_{u\to v}(X) = X(T)$ 定义的映射 $\Gamma_{u\to v}(X) : T_u\Omega \to T_u\Omega$ 与 $T_v\Omega$ 称为平行移动或联络；后一名称意味着它是“连接”切空间 $T_u\Omega$ 与 $T_v\Omega$ 的机制。由于保持夹角和长度的条件，平行移动相当于仅对向量作旋转，因此可与特殊正交群 $SO(s)$ 的一个元素联系起来；该群称为切丛的结构群，我们将其记为 $g_{u\to v}$，并将在第 4.5 节进一步讨论。[38]

如前所述，联络可以独立于黎曼度量公理化定义，从而为沿任意光滑曲线的平行移动提供抽象概念。然而，这种移动的结果依赖于所走的路径。

指数映射 在点 u 的局部，总可以在给定方向 $X \in T_u\Omega$ 上定义唯一测地线，即满足 $\gamma(0) = u$、$\gamma'(0) = X$ 的测地线。当 $\gamma_X(t)$ 对所有 $t \geq 0$ 都有定义

[38]这里假定流形可定向；否则为 $O(s)$。

（即从点 u 出发可以沿测地线走任意长时间）时，称流形是测地完备的，指数映射也就在整个切空间上有定义。由于紧流形是测地完备的，我们可以默认这一方便的性质。

由点和方向给出测地线的定义，自然产生一个从切空间 $T_u\Omega$ 的（子集）到 Ω 的映射，称为指数映射 $\exp : B_r(0) \subset T_u\Omega \to \Omega$；其定义是沿方向 X 的测地线走单位步长，即 $\exp_u(X) = \gamma_X(1)$。指数映射 $\exp_u$ 是局部微分同胚，因为它将 $T_u\Omega$ 上原点的邻域 $B_r(0)$（半径为 r 的球）形变到 u 的邻域。反过来，也可以把指数映射看作将流形内禀地局部形变（“展平”）到切空间。[39]

测地距离 称为 Hopf–Rinow 定理的结果保证测地完备流形也是完备度量空间，在其中可以将任意两点 u, v 之间的距离（称为测地距离或度量）实现为两点之间最短路径的长度：[40]

$$d_g(u,v) = \min_{\gamma} \ell(\gamma) \quad \text{满足} \quad \gamma(0) = u,\ \gamma(T) = v,$$

这一最小值存在，即可以达到。[41]

等距映射 现在考虑将流形 Ω 形变为另一个赋有黎曼度量 h 的流形 $\widetilde{\Omega}$；我们假定这一形变是流形之间的微分同胚 $\eta : (\Omega, g) \to (\widetilde{\Omega}, h)$。其微分 $d\eta : T\Omega \to T\widetilde{\Omega}$ 定义了相应切丛之间的映射（称为推前），使得在点 u 处有 $d\eta_u : T_u\Omega \to T_{\eta(u)}\widetilde{\Omega}$。它可以如前解释：若从点 u 沿切向量 $X \in T_u\Omega$ 作微小位移，则映射 η 将从点 $\eta(u)$ 沿切向量 $d\eta_u(X) \in T_{\eta(u)}\widetilde{\Omega}$ 发生位移。

由于推前提供了关联两个流形上切向量的机制，我们可以将 $\widetilde{\Omega}$ 上的度

[39]注意，测地完备不一定保证 exp 为全局微分同胚。关于 u，使 $\exp_u(B_r(0) \subseteq T_u\Omega)$ 被微分同胚地映射的最大半径 r 称为单射半径。

[40]Hopf–Rinow 定理由此建立了测地完备与度量完备的等价性；后者意味着在测地距离度量下每个 Cauchy 序列都收敛。

[41]注意“度量”一词有两种含义：黎曼度量 g 和距离 d。为避免混淆，我们用“距离”指后者。记号 d_g 表明距离依赖于黎曼度量 g，而测地长度 L 的定义亦依赖于它。

量 h 拉回到 Ω，在每一点定义为[42]

$$(\eta^* h)_u(X, Y) = h_{\eta(u)}(d\eta_u(X), d\eta_u(Y)).$$

如果拉回度量在每一点都与 Ω 的度量一致，即 $g = \eta^* h$，则称映射 η 为（黎曼）等距映射。对于二维流形（曲面），可以直观地将等距映射理解为非弹性形变：它改变流形形状，但不“拉伸”或“撕裂”流形。

根据定义，等距映射保持可以完全由黎曼度量表达的内禀结构，例如测地距离。因此，也可以从度量几何的角度理解等距映射：它是度量空间之间保持距离的映射（“度量等距映射”）$\eta : (\Omega, d_g) \to (\widetilde{\Omega}, d_h)$，即对所有 $u, v \in \Omega$，

$$d_g(u, v) = d_h(\eta(u), \eta(v)),$$

或者更紧凑地写为 $d_g = d_h \circ (\eta \times \eta)$。换言之，黎曼等距映射也是度量等距映射。在连通流形上，逆命题也成立：每个度量等距映射也是黎曼等距映射。[43]

在几何深度学习蓝图中，η 是定义域形变的模型。当 η 是等距映射时，任何内禀量都不受这种形变影响。可以通过度量伸缩率或度量失真的概念推广精确的（度量）等距映射：

$$\begin{aligned} \operatorname{dil}(\eta) &= \sup_{u \neq v \in \Omega} \frac{d_h(\eta(u), \eta(v))}{d_g(u, v)}, \\ \operatorname{dis}(\eta) &= \sup_{u, v \in \Omega} |d_h(\eta(u), \eta(v)) - d_g(u, v)|, \end{aligned}$$

它们分别刻画 η 下测地距离的相对变化和绝对变化。[44]在此情形下，函数 $f \in \mathcal{F}(\mathcal{X}(\Omega))$ 在定义域形变下稳定的条件 (5) 可改写为

$$\|f(x, \Omega) - f(x \circ \eta^{-1}, \widetilde{\Omega})\| \leq C \|x\| \operatorname{dis}(\eta).$$

---

[42]推前和拉回是伴随算子：$\langle \eta^* \alpha, X \rangle = \langle \alpha, \eta_* X \rangle$，其中 $\alpha \in T^*\Omega$ 是对偶向量场，在每点被定义为作用于 $T_u\Omega$ 的线性泛函；两侧内积分别定义在向量场和对偶向量场上。

[43]这个结果称为 Myers–Steenrod 定理。这里默认流形连通。

[44]第 3.2 节提到的度量空间间 Gromov–Hausdorff 距离，可以表示为可能达到的最小度量失真。

内禀对称性 上述情况的一个特例是定义域自身的微分同胚（第 3.2 节称其为自同构），记为 $\tau \in \mathrm{Diff}(\Omega)$。若拉回度量满足 $\tau^* g = g$，则称其为黎曼（自）等距映射；若 $d_g = d_g \circ (\tau \times \tau)$，则称其为度量（自）等距映射。不出所料，等距映射在复合运算下构成一个群，记为 $\mathrm{Iso}(\Omega)$，称为等距群；其单位元是映射 $\tau(u) = u$，而逆元总是存在（由 τ 作为微分同胚的定义）。因此，自等距映射是流形的内禀对称性。[45]

流形上的傅里叶分析 我们现在说明如何在流形上构造内禀的类卷积操作；按照构造，这些操作将对等距形变不变。为此有两种选择：一种是利用傅里叶变换的类比，将卷积定义为傅里叶域中的乘积；另一种是在空间上通过滤波器与信号的局部相关来定义卷积。先讨论谱方法。

回顾一下，在欧几里得定义域中，傅里叶变换通过循环矩阵的特征向量得到；循环矩阵由于彼此交换而可同时对角化。因此，任何循环矩阵，特别是微分算子，都可以用来在一般定义域上定义傅里叶变换的类似物。在黎曼几何中，常用拉普拉斯算子的正交特征基，我们将在这里定义该算子。

为此，回忆内禀梯度算子 $\nabla : \mathcal{X}(\Omega, \mathbb{R}) \to \mathcal{X}(\Omega, T\Omega)$ 的定义：它产生一个切向量场，指出流形上标量场局部增长最快的方向。类似地，可以定义散度算子 $\nabla^* : \mathcal{X}(\Omega, T\Omega) \to \mathcal{X}(\Omega, \mathbb{R})$。如果将切向量场视为流形上的流，散度就衡量该场在一点处的净流量，从而区分场的 “源” 和 “汇”。我们使用记号 ∇^*（而不是常见的 div）来强调两个算子互为伴随：

$$\langle X, \nabla x \rangle = \langle \nabla^* X, x \rangle,$$

其中使用了标量场和向量场之间的内积 (15) 和 (16)。

拉普拉斯算子（在微分几何中也称 Laplace–Beltrami 算子）是 $\mathcal{X}(\Omega)$ 上定义为 $\Delta = \nabla^* \nabla$ 的算子；它可以解释为某点周围无穷小球面上函数的平均值与该点函数值之间的差。[46]它是数学物理中最重要的算子之一，用于描述

[45]流形上的连续对称性由称为 Killing 场的特殊切向量场无穷小生成，以 Wilhelm Killing 命名。

[46]从这一解释也可以看出拉普拉斯算子是各向同性的。我们将在第 4.6 节看到，可以定义形式为 $\nabla^*(A(u)\nabla)$ 的各向异性拉普拉斯算子（见 Andreux et al.（2014）、Boscaini et al.（2016b））, 其中 $A(u)$ 是决定局部方向的依位置而变的张量。

热扩散、量子振荡和波传播等各种现象。对我们的讨论而言，重要的是拉普拉斯算子是内禀的，因此在 Ω 的等距映射下不变。

容易看出拉普拉斯算子是自伴的（“对称的”）：

$$\langle \nabla x, \nabla x \rangle = \langle x, \Delta x \rangle = \langle \Delta x, x \rangle.$$

上式左侧的二次型实际上就是已经熟悉的狄利克雷能量，衡量 x 的光滑性：

$$c^2(x) = \|\nabla x\|^2 = \langle \nabla x, \nabla x \rangle = \int_\Omega \|\nabla x(u)\|_u^2 \, du = \int_\Omega g_u(\nabla x(u), \nabla x(u)) \, du.$$

拉普拉斯算子具有特征分解 $\Delta \phi_k = \lambda_k \phi_k$，$k = 0, 1, \ldots$。若流形紧致（我们默认如此），其谱可数；由于 Δ 自伴，特征函数正交，即 $\langle \phi_k, \phi_l \rangle = \delta_{kl}$。拉普拉斯特征基还可以构造为狄利克雷能量的一组正交极小化解：

$$\phi_{k+1} = \arg\min_{\phi} \|\nabla \phi\|^2 \quad \text{满足} \quad \|\phi\| = 1 \text{ 且 } \langle \phi, \phi_j \rangle = 0, \quad j = 0, \ldots, k,$$

因此可以将其理解为 Ω 上最光滑的正交基。特征函数 $\phi_0, \phi_1, \ldots$ 及相应特征值 $0 = \lambda_0 \le \lambda_1 \le \cdots$，可以类比为经典傅里叶变换中的原子和频率。[47]

这一正交基允许将 Ω 上的平方可积函数展开为傅里叶级数：

$$x(u) = \sum_{k \ge 0} \langle x, \phi_k \rangle \phi_k(u),$$

其中 $\widehat{x}_k = \langle x, \phi_k \rangle$ 称为傅里叶系数或 x 的（广义）傅里叶变换。截断傅里叶级数会产生逼近误差，可以将其界定为（Aflalo and Kimmel，2013）[48]

$$\left\| x - \sum_{k=0}^{N} \langle x, \phi_k \rangle \phi_k \right\|^2 \le \frac{\|\nabla x\|^2}{\lambda_{N+1}}.$$

Aflalo et al.（2015）进一步表明，没有其他基能达到更好的误差，因此拉普拉斯特征基是表示流形上光滑信号的最优基。

---

[47] 事实上，$e^{i\xi u}$ 是欧几里得拉普拉斯算子 d^2/du^2 的特征函数。

[48] 注意该傅里叶变换具有离散指标，因为 Ω 的紧致性使得谱离散。

流形上的谱卷积 谱卷积可定义为信号 x 与滤波器 θ 的傅里叶变换之积：

$$(x \star \theta)(u) = \sum_{k \geq 0} (\widehat{x}_k \cdot \widehat{\theta}_k) \phi_k(u). \tag{17}$$

注意，这里我们将经典傅里叶变换的一项性质（卷积定理）用作定义非欧几里得卷积的方法。根据其构造，谱卷积是内禀的，因而对等距映射不变。此外，由于拉普拉斯算子各向同性，它没有方向概念；在这一意义上，情况与第 4.1 节中由于邻居聚合的置换不变性而出现的图上情形相似。



图 12: 谱滤波器在定义域扰动下的不稳定性。左：网格 Ω 上的信号 x。中：在 Ω 上拉普拉斯算子 Δ 的特征基中进行谱滤波的结果。右：将相同的谱滤波器应用于近似等距扰动后的定义域 $\widetilde{\Omega}$ 上拉普拉斯算子 $\widetilde{\Delta}$ 的特征向量，产生了非常不同的结果。

在实践中，由于需要将拉普拉斯算子对角化，直接计算式 (17) 似乎代价高得难以承受。更糟的是，它在几何上不稳定：即使定义域 Ω 只经历很小的近似等距扰动，拉普拉斯算子的高频特征函数也可能发生剧烈变化（见图 12）。更稳定的解决办法是将滤波器实现为形式为 $\widehat{p}(\Delta)$ 的谱传递函数：

$$(\widehat{p}(\Delta)x)(u) = \sum_{k \geq 0} \widehat{p}(\lambda_k) \langle x, \phi_k \rangle \phi_k(u), \tag{18}$$

$$= \int_\Omega x(v) \sum_{k \geq 0} \widehat{p}(\lambda_k) \phi_k(v) \phi_k(u) \, dv. \tag{19}$$

这可以有两种解释：既可以将式 (18) 视为谱滤波器，其中令 $\widehat{\theta}_k = \widehat{p}(\lambda_k)$；也可以将式 (19) 视为位置相关核 $\theta(u, v) = \sum_{k \geq 0} \widehat{p}(\lambda_k) \phi_k(v) \phi_k(u)$ 的空间滤波器。

此表述的优点是 $\widehat{p}(\lambda)$ 可由少量系数参数化。对于多项式 $\widehat{p}(\lambda) = \sum_{l=0}^{r} \alpha_l \lambda^l$，滤波器可高效计算：

$$(\widehat{p}(\Delta)x)(u) = \sum_{k\geq 0}\sum_{l=0}^{r} \alpha_l \lambda_k^l \langle x, \phi_k\rangle \phi_k(u) = \sum_{l=0}^{r} \alpha_l (\Delta^l x)(u),$$

完全避免谱分解。我们将在第 4.6 节进一步讨论这一构造。[49]

流形上的空间卷积 另一种尝试是在不同点匹配滤波器，以定义流形上的卷积，如式 (14)：

$$(x \star \theta)(u) = \int_{T_u\Omega} x(\exp_u Y)\theta_u(Y)\, dY, \tag{20}$$

此处需要用指数映射从切空间访问标量场 x 的值；滤波器 θ_u 定义在每一点的切空间中，因此依赖位置。若以内禀方式定义滤波器，这样的卷积将对等距映射不变；如前所述，该性质在许多计算机视觉和图形学应用中至关重要。

然而，我们需要指出这与第 4.2–4.3 节先前构造之间的若干重大区别。首先，由于流形一般不是齐性空间，我们不再拥有全局群结构，不能在一点定义共享滤波器（即每个 u 处使用相同的 θ，而不是式 (20) 中的 θ_u），然后将其移动到各处。在流形上类比这一操作需要平行移动，使得定义为 $T_u\Omega$ 上函数的共享 θ 能够应用到其他 $T_v\Omega$。但如前所见，这通常依赖于 u, v 之间的路径，因此移动滤波器的方式很重要。第三，由于只能在局部使用指数映射，滤波器必须是局部的，其支撑受单射半径限制。第四，也是最关键的一点，我们不能直接处理 $\theta(X)$，因为 X 是抽象几何对象；为了计算，必须相对于某个局部基 $\omega_u : \mathbb{R}^s \to T_u\Omega$，将它表示为 s 维坐标数组 $\mathbf{x} = \omega_u^{-1}(X)$。这样便可以将卷积 (20) 改写为

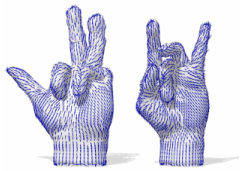
$$(x \star \theta)(u) = \int_{[0,1]^s} x(\exp_u(\omega_u \mathbf{y}))\theta(\mathbf{y})\, d\mathbf{y}, \tag{21}$$

其中滤波器定义在单位立方体上。由于指数映射（通过测地线的定义）是内禀的，所得卷积对等距映射不变。

[49] 基于通过傅里叶变换表达的谱卷积的几何深度学习方法，通常称为“谱”方法，以区别于前面在图的背景下见到的“空间”方法。我们在此看到，这两种观点可能等价，因此这种二分有些人为，并不完全恰当。

然而，这默认我们可以将标架 ω_u 带到另一个流形，即 $\omega'_u = d\eta_u \circ \omega_u$。仅给定流形 Ω，要以一致方式获得这种标架（或物理学术语中的规范）却困难重重。首先，光滑的全局规范可能不存在：这发生在不可平行化的流形上，此时无法定义处处非零的光滑切向量场。[50]其次，流形上不存在规范的标准选择，因此这个选择是任意的；由于卷积依赖于 ω，若选用不同规范，就会得到不同结果。

应当指出，这里实践与理论有所不同：实践中可以构造大部分区域光滑、只有有限个奇点的标架，例如取流形上某个内禀标量场的内禀梯度。此外，这种构造是稳定的，即按这种方式构造的标架在等距流形上相同，在近似等距流形上相似。早期流形深度学习工作确实使用了这类方法（Masci et al.，2015；Monti et al.，2017）。



利用 Melzi et al.（2019）的 GFrames 算法，在近似等距流形上构造稳定规范的例子（仅显示一个轴）。

尽管如此，这一解决方案并不完全令人满意：在奇点附近，滤波器方向（相对于规范以固定方式定义）会剧烈变化，即使输入信号和滤波器都是光滑的，也会导致非光滑的特征图。此外，没有明确理由认为某点 u 的给定方向应与完全不同的点 v 的某一方向等价。因此，尽管有实践上的替代方法，接下来我们仍将寻找理论基础更坚实、完全不依赖规范选择的方法。

4.5 规范与丛

我们将规范定义为切空间的标架，但物理学中的规范概念要宽泛得多：它可以指任意向量丛的标架，而不只是切丛。非正式地说，向量丛描述由另

[50]球面 S^2 是不可平行化流形的例子，这是 Poincaré–Hopf 定理的结果；通俗地说，“无法把毛球梳平而不留下发旋”。

一个空间参数化的一族向量空间：它由基空间 Ω 构成，在每个位置 $u \in \Omega$ 处附着一个相同的向量空间 $\mathbb{V}$（称为纤维）；对于切丛，这些纤维就是切空间 $T_u\Omega$。[51]粗略地说，在 u 周围局部来看，丛像乘积 $\Omega \times \mathbb{V}$，但整体上可能“扭曲”并具有不同的整体结构。在几何深度学习中，可以用纤维对流形 Ω 上每一点的特征空间建模，其维数等于特征通道数。在这种背景下，可能出现一种新的、引人入胜的对称性，称为规范对称性。

再次考虑 s 维流形 Ω、其切丛 $T\Omega$ 以及向量场 $X : \Omega \to T\Omega$（在这里的术语中称为切丛的截面）。相对于切丛的规范 ω，X 被表示为函数 $\mathbf{x} : \Omega \to \mathbb{R}^s$。然而，重要的是要认识到，我们真正关心的是底层几何对象（向量场），而它作为函数 $\mathbf{x} \in \mathcal{X}(\Omega, \mathbb{R}^s)$ 的表示依赖规范 ω 的选择。改变规范时，我们也需要改变 $\mathbf{x}$，以保持所表示的底层向量场不变。

切丛与结构群 改变规范时，需要在每一点应用一个可逆矩阵，将旧规范映到新规范。在每一点，对每对规范而言该矩阵唯一，但它在不同点可能不同。换言之，规范变换是映射 $\mathfrak{g} : \Omega \to GL(s)$，其中 $GL(s)$ 是可逆 $s \times s$ 矩阵的一般线性群。它作用于规范 $\omega_u : \mathbb{R}^s \to T_u\Omega$，产生新规范 $\omega'_u = \omega_u \circ \mathfrak{g}_u : \mathbb{R}^s \to T_u\Omega$。规范变换在每一点通过 $\mathbf{x}'(u) = \mathfrak{g}_u^{-1}\mathbf{x}(u)$ 作用于坐标向量场，产生 X 相对于新规范的坐标表示 $\mathbf{x}'$。底层向量场保持不变：

$$X(u) = \omega'_u(\mathbf{x}'(u)) = \omega_u(\mathfrak{g}_u\mathfrak{g}_u^{-1}\mathbf{x}(u)) = \omega_u(\mathbf{x}(u)) = X(u),$$

这正是我们所需的性质。更一般地，可以有一个按 $GL(s)$ 的表示 ρ 变换的几何量场，例如 2 阶张量（矩阵）场 $A(u) \in \mathbb{R}^{s \times s}$，其变换方式为

$$A'(u) = \rho_2(\mathfrak{g}_u^{-1})A(u) = \rho_1(\mathfrak{g}_u)A(u)\rho_1(\mathfrak{g}_u^{-1}).$$

在此情况下，规范变换 $\mathfrak{g}_u$ 通过 $\rho(\mathfrak{g}_u)$ 作用。

有时，我们希望只关注具有某种性质的标架，例如正交标架、右手标架等。不出所料，我们关心的是保持某种性质且构成群的一组变换。例如，保持正交性的群是正交群 $O(s)$（旋转和反射），进一步保持定向或“手性”的群则是 $SO(s)$（纯旋转）。因此，一般而言，我们有一个称为丛的结构群的

[51]从历史上看，纤维丛首先出现在 Élie Cartan 的现代微分几何中（虽然他没有显式定义它们），随后在 20 世纪 30 年代的拓扑学领域作为独立对象进一步发展。

群 $\mathfrak{G}$，规范变换是映射 $\mathfrak{g} : \Omega \to \mathfrak{G}$。关键观察是：对于具有给定性质的所有情形，在某一点给定任意两个标架，都存在恰好一个将二者联系起来的规范变换。

如前所述，规范理论不局限于切丛；一般而言，可以考虑其结构和维数不一定与基空间 Ω 相关的向量空间丛。例如，彩色图像的像素在二维网格上具有位置 $u \in \Omega = \mathbb{Z}^2$，并在 RGB 空间中具有值 $\mathbf{x}(u) \in \mathbb{R}^3$；因此，像素空间可以视为一个向量丛，其基空间为 $\mathbb{Z}^2$，每一点附着纤维 $\mathbb{R}^3$。[52]通常用具有 R、G、B 基向量（按此顺序）的规范表示 RGB 图像，使图像的坐标表示为 $\mathbf{x}(u) = (r(u), g(u), b(u))^\top$。但也完全可以在每个位置独立置换基向量（颜色通道），只要记住每一点所使用的标架（通道顺序）即可。

作为计算操作，这么做颇无意义；但正如下文将看到的，从概念上考虑 RGB 颜色空间的规范变换是有用的，因为它允许我们表达规范对称性——在这里即颜色之间的等价性——并使定义在图像上的函数尊重这种对称性（同等对待每种颜色）。[53]

与流形上的向量场一样，RGB 规范变换改变的是图像的数值表示（在每个像素独立置换 RGB 值），而不是底层图像。在机器学习应用中，我们希望构造作用于这类图像的函数 $f \in \mathcal{F}(\mathcal{X}(\Omega))$（例如执行图像分类或分割），并以神经网络层实现。由此可知，如果由于某种原因对图像应用规范变换，也需要改变函数 f（网络层）以保持其含义。为简单起见，考虑 1×1 卷积，即将 RGB 像素 $\mathbf{x}(u) \in \mathbb{R}^3$ 映到特征向量 $\mathbf{y}(u) \in \mathbb{R}^C$ 的映射。根据几何深度学习蓝图，输出与群表示 ρ_{out} 相关联，在本例中它是结构群 $\mathfrak{G} = \Sigma_3$（RGB 通道置换）的 C 维表示；同样，输入与表示 $\rho_{\text{in}}(\mathfrak{g}) = \mathfrak{g}$ 相关联。

因此，如果对输入应用规范变换，需要将线性映射（1×1 卷积）$f : \mathbb{R}^3 \to \mathbb{R}^C$ 改为 $f' = \rho_{\text{out}}^{-1}(\mathfrak{g}) \circ f \circ \rho_{\text{in}}(\mathfrak{g})$，使输出特征向量 $\mathbf{y}(u) = f(\mathbf{x}(u))$ 在

[52]我们用 s 表示基空间 Ω 的维数，用 d 表示纤维的维数。对于切丛，$d = s$ 是底层流形的维数；对于 RGB 图像，$s = 2$、$d = 3$。

[53]在这个例子中，我们选择三个颜色通道的置换群 $\mathfrak{G} = \Sigma_3$ 作为丛的结构群。也可以选择其他群，例如色相旋转 $\mathfrak{G} = SO(2)$。

每一点按 $\mathbf{y}'(u) = \rho_{\text{out}}(\mathfrak{g}_u)\mathbf{y}(u)$ 变换。事实上，可以验证：[54]

$$\mathbf{y}' = f'(\mathbf{x}') = \rho_{\text{out}}^{-1}(\mathfrak{g}) f\big(\rho_{\text{in}}(\mathfrak{g})\rho_{\text{in}}^{-1}(\mathfrak{g})\mathbf{x}\big) = \rho_{\text{out}}^{-1}(\mathfrak{g}) f(\mathbf{x}).$$

规范对称性 称规范变换为对称性，意味着任何两个通过规范变换联系的规范都应视为等价。例如，若取 $\mathfrak{G} = SO(d)$，则任意两个右手正交标架都被视为等价，因为可以通过旋转将其中任一标架映到另一标架。换言之，不存在“上”或“右”之类特殊的局部方向。类似地，若 $\mathfrak{G} = O(d)$（正交群），任意左手和右手正交标架都被视为等价，此时也没有优先的定向。一般地，我们可以考虑一个群 $\mathfrak{G}$ 以及每点 u 处的一组标架，使其中任意两个标架之间都存在唯一的 $\mathfrak{g}(u) \in \mathfrak{G}$ 将一个映到另一个。

在几何深度学习蓝图中将规范变换视为对称性时，我们希望作用于定义在 Ω 上、相对于规范表示的信号的函数 f，对这类变换等变。具体地说，若对输入应用规范变换，输出也应发生相同变换（可能通过 $\mathfrak{G}$ 的不同表示作用）。前面已经指出，改变规范时函数 f 也应改变，但对于规范等变映射则并非如此：改变规范使该映射保持不变。

为此再次考虑 RGB 颜色空间例子。映射 $f : \mathbb{R}^3 \to \mathbb{R}^C$ 是等变的，如果 $f \circ \rho_{\text{in}}(\mathfrak{g}) = \rho_{\text{out}}(\mathfrak{g}) \circ f$；但在这种情况下，作用于 f 的规范变换没有效果：$\rho_{\text{out}}^{-1}(\mathfrak{g}) \circ f \circ \rho_{\text{in}}(\mathfrak{g}) = f$。换言之，规范等变映射的坐标表达不依赖规范，这与图的情形类似：无论输入节点如何置换，我们都应用相同的函数。然而，不同于此前讨论的图和其他例子，规范变换不作用于 Ω，而是在每个 $u \in \Omega$ 处通过变换 $\mathfrak{g}(u) \in \mathfrak{G}$，分别作用于各个特征向量 $\mathbf{x}(u)$。

考察具有更大空间支撑的流形滤波器时，还需要考虑更多因素。先看一个简单例子：s 维流形 Ω 上标量场到标量场的映射 $f : \mathcal{X}(\Omega, \mathbb{R}) \to \mathcal{X}(\Omega, \mathbb{R})$。不同于向量和其他几何量，标量没有方向，因此标量场 $x \in \mathcal{X}(\Omega, \mathbb{R})$ 对规范变换不变（它按平凡表示 $\rho(\mathfrak{g}) = 1$ 变换）。因此，标量场到标量场的任何线性映射都是规范等变的（或称不变，在此情形二者相同）。例如，可以类似于式 (19)，将 f 写为具有位置相关滤波器 $\theta : \Omega \times \Omega \to \mathbb{R}$ 的类卷积操作：

$$(x \star \theta)(u) = \int_\Omega \theta(u, v) x(v)\, dv. \tag{22}$$

[54] 此处记号 $\rho^{-1}(\mathfrak{g})$ 应理解为群表示矩阵 $\rho(\mathfrak{g})$ 的逆。

这意味着在每一点都可能有不同的滤波器 $\theta_u = \theta(u, \cdot)$，即没有空间权重共享；单靠规范对称性并不能提供这种共享。

再考虑向量场之间的映射 $f : \mathcal{X}(\Omega, T\Omega) \to \mathcal{X}(\Omega, T\Omega)$。相对于某个规范，输入和输出向量场 $X, Y \in \mathcal{X}(\Omega, T\Omega)$ 是向量值函数 $\mathbf{x}, \mathbf{y} \in \mathcal{X}(\Omega, \mathbb{R}^s)$。这类函数之间的一般线性映射可以用与标量相同的式 (22) 写出，只需将标量核替换为矩阵值核 $\Theta : \Omega \times \Omega \to \mathbb{R}^{s\times s}$。矩阵 $\Theta(u, v)$ 应将 $T_v\Omega$ 中的切向量映到 $T_u\Omega$ 中的切向量，但这两点有不同的规范，可分别任意改变。也就是说，滤波器需要对所有 $u, v \in \Omega$ 满足 $\Theta(u, v) = \rho^{-1}(\mathfrak{g}(u))\Theta(u, v)\rho(\mathfrak{g}(v))$，其中 ρ 表示 $\mathfrak{G}$ 在向量上的作用，由一个 $s \times s$ 旋转矩阵给出。由于 $\mathfrak{g}(u)$ 和 $\mathfrak{g}(v)$ 可自由选择，这对滤波器的约束过强。[55]

更好的方法是先通过联络将向量移动到同一个切空间，再仅对一点处的单个规范变换施加规范等变性。于是，代替式 (22)，可以定义向量场之间的映射：

$$(\mathbf{x} \star \Theta)(u) = \int_\Omega \Theta(u, v)\rho(g_{v\to u})\mathbf{x}(v)\, dv, \tag{23}$$

其中 $g_{v\to u} \in \mathfrak{G}$ 表示沿连接两点的测地线从 v 到 u 的平行移动；其表示 $\rho(g_{v\to u})$ 是一个 $s \times s$ 旋转矩阵，随着向量在两点之间移动而将其旋转。注意，这里假定测地线唯一，这只在局部成立，因此滤波器必须具有局部支撑。在规范变换 $\mathfrak{g}_u$ 下，该元素按 $g_{u\to v} \mapsto \mathfrak{g}_u^{-1} g_{u\to v}\mathfrak{g}_v$ 变换，而场本身按 $\mathbf{x}(v) \mapsto \rho(\mathfrak{g}_v)\mathbf{x}(v)$ 变换。如果滤波器与结构群表示交换，即 $\Theta(u, v)\rho(\mathfrak{g}_u) = \rho(\mathfrak{g}_u)\Theta(u, v)$，那么式 (23) 定义了一个规范等变卷积，在上述变换下满足

$$(\mathbf{x}' \star \Theta)(u) = \rho^{-1}(\mathfrak{g}_u)(\mathbf{x} \star \Theta)(u).$$

4.6 几何图与网格

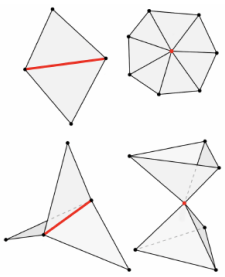
我们将以几何图（即可以在某个几何空间中实现的图）和网格结束对不同几何定义域的讨论。在几何定义域的“五个 G”中，网格介于图和流形之间：在许多方面它们类似于图，但其额外结构也允许我们以类似连续对象的

[55] 在这种情况下 Θ 确实必须为零。

方式处理它们。因此，我们在方案中不把网格视作独立对象；事实上，我们将强调本节对网格推导的许多构造也可以直接应用于一般图。

如第 4.4 节所述，二维流形（曲面）是三维对象（更确切地说，是这些对象的边界曲面）的常用模型。在计算机图形学和视觉应用中，这种曲面常被离散化为三角网格，可以粗略地将其理解为沿边将三角形粘合起来而获得的曲面的分片平面近似。[56]因此，网格是具有额外结构的（无向）图：除了节点和边，网格 $\mathcal{T} = (\mathcal{V}, \mathcal{E}, \mathcal{F})$ 还有由有序节点三元组构成的三角形面，$\mathcal{F} = \{(u, v, q) : u, v, q \in \mathcal{V} \text{ 且} (u, v), (u, q), (q, v) \in \mathcal{E}\}$；节点顺序定义面的定向。

进一步假定每条边恰由两个三角形共享，并且与每个节点相接的所有三角形的边界形成单一的边环。该条件保证每个节点周围的一跳邻域形如圆盘，因而网格构成离散流形；这样的网格称为流形网格。与黎曼流形类似，我们可以在网格上定义度量。最简单的情形下，可以从网格节点 $\mathbf{x}_1, \ldots, \mathbf{x}_n$ 的嵌入诱导度量，并用边的欧几里得长度表示：$\ell_{uv} = \|\mathbf{x}_u - \mathbf{x}_v\|$。这样定义的度量自动满足三角不等式等性质，即对任意 $(u, v, q) \in \mathcal{F}$ 及其边的任意组合，有 $\ell_{uv} \le \ell_{uq} + \ell_{vq}$ 之类的表达式。任何仅能由 ℓ 表达的性质都是内禀的，保持 ℓ 的任何网格形变都是等距映射；这些概念在第 4.4 节中已经介绍。



流形（上）和非流形（下）的边与节点示例。对于带边界流形，还需定义只属于一个三角形的边界边。

拉普拉斯矩阵 类比对图的处理，假定一个有 n 个节点的（流形）网格，每个节点关联一个 d 维特征向量；这些向量可以按任意顺序排列成 $n \times d$ 矩阵

[56]三角网格是称为单纯复形的一类拓扑结构的例子。

$\mathbf{X}$。特征既可以表示节点的几何坐标，也可以表示颜色、法向量等附加性质；在化学等具体应用中，几何图对分子建模时，特征还可以表示原子序数等性质。

先看网格上的谱卷积 (17)，它来自拉普拉斯算子。将网格视为底层连续曲面的离散化，可以将拉普拉斯算子离散化为

$$(\Delta\mathbf{X})_u = \sum_{v\in\mathcal{N}_u} w_{uv}(\mathbf{x}_u - \mathbf{x}_v), \tag{24}$$

或用矩阵—向量记号表示为 $n \times n$ 对称矩阵 $\Delta = D - W$，其中 $D = \mathrm{diag}(d_1, \dots, d_n)$ 称为度矩阵，$d_u = \sum_v w_{uv}$ 是节点 u 的度。容易看出，式 (24) 对邻居特征进行局部置换不变聚合 $\phi(\mathbf{x}_u, \mathbf{X}_{\mathcal{N}_u}) = d_u\mathbf{x}_u - \sum_{v\in\mathcal{N}_u} w_{uv}\mathbf{x}_v$，而 $\mathbf{F}(\mathbf{X}) = \Delta\mathbf{X}$ 实际上是构造图上置换等变函数的一般蓝图 (13) 的一个实例。

注意，到目前为止，式 (24) 中拉普拉斯算子的定义没有任何网格特有之处；事实上，它对任意图也有效，此时将边权识别为邻接矩阵 $W = A$，即当 $(u, v) \in \mathcal{E}$ 时 $w_{uv} = 1$，否则为零。[57]这样构造的拉普拉斯算子常称为组合拉普拉斯算子，反映它们只捕捉图的连接结构。对于几何图（不一定具有网格的额外结构，但节点具有空间坐标，并以边长形式诱导度量），常使用与度量反向相关的权重，例如 $w_{uv} \propto e^{-\ell_{uv}}$。

在网格上，可以利用面提供的额外结构，通过余切公式定义式 (24) 中的边权（Pinkall and Polthier，1993；Meyer et al.，2003）：

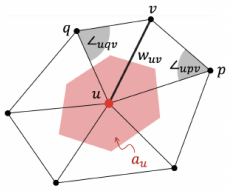
$$w_{uv} = \frac{\cot\angle uqv + \cot\angle upv}{2a_u}, \tag{25}$$

其中 $\angle uqv$ 和 $\angle upv$ 分别是三角形 (u, q, v) 和 (u, p, v) 中与公共边 (u, v) 相对的两个角，a_u 是局部面积元，通常计算为以共享节点 u 的三角形 (u, p, q) 的重心构造出的多边形面积，给定为 $a_u = \frac{1}{3}\sum_{v,q:(u,v,q)\in\mathcal{F}} a_{uvq}$。[58]

可以证明余切拉普拉斯算子具有多种方便的性质（例如 Wardetzky et al.（2007））：它是正半定矩阵，$\Delta \succeq 0$，因此具有非负特征值 $\lambda_1 \le \cdots \le \lambda_n$，可视为频率的类比；它是对称的，因此特征向量正交；并且它是局部的，即

[57]此时度等于邻居数。如果图有向，相应拉普拉斯矩阵非对称。

[58]这一公式最早可追溯到 MacNeal（1949）的博士论文；他开发该公式以在加州理工电模拟计算机上求解偏微分方程。



余切权重中的相对角、边和局部面积元。

$(\Delta \mathbf{X})_u$ 的值只依赖一跳邻居 $\mathcal{N}_u$。或许最重要的性质是，当网格被无限细化时，余切网格拉普拉斯矩阵 Δ 收敛到连续算子 Δ（Wardetzky，2008）。[59]因此，式 (25) 构成第 4.4 节中定义在黎曼流形上的拉普拉斯算子的适当离散化。

虽然我们期望拉普拉斯算子是内禀的，但从式 (25) 看并不十分明显，需要一定工作才能完全用离散度量 ℓ 表示余切权重：

$$w_{uv} = \frac{-\ell_{uv}^2 + \ell_{vq}^2 + \ell_{uq}^2}{8a_{uvq}} + \frac{-\ell_{uv}^2 + \ell_{vp}^2 + \ell_{up}^2}{8a_{uvp}},$$

其中三角形面积 a_{ijk} 由海伦半周长公式给出：

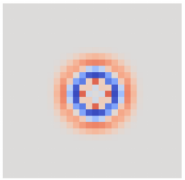
$$\begin{aligned} a_{uvq} &= \sqrt{s_{uvq}(s_{uvq} - \ell_{uv})(s_{uvq} - \ell_{vq})(s_{uvq} - \ell_{uq})}, \\ s_{uvq} &= \tfrac{1}{2}(\ell_{uv} + \ell_{uq} + \ell_{vq}). \end{aligned}$$

这赋予拉普拉斯算子及与其相关的任何量（例如特征向量和特征值）等距不变性；正因这一性质，它在几何处理和计算机图形学中深受欢迎（参见 Wang and Solomon（2019）的优秀综述）：任何不影响度量 ℓ（不“拉伸”或“挤压”网格边）的网格形变都不改变拉普拉斯算子。

最后，如前所述，拉普拉斯算子 (25) 的定义对 $\mathcal{N}_u$ 中节点的置换不变，因为它使用求和聚合。在一般图上，由于邻居缺乏标准顺序，这是不得不接受的限制；在网格上，我们可以按某种定向（例如顺时针）排列一跳邻居，唯一的歧义是第一个节点的选择。因此，不必考虑任意置换，只需考虑循环

[59]细化必须满足某些技术条件，以避免例如三角形退化。其中一个例子是圆柱的一种奇异三角剖分，德语称为 Schwarzscher Stiefel（Schwarz 的靴子），英语文献称为“Schwarz 灯笼”，由以 Cauchy–Schwarz 不等式闻名的德国数学家 Hermann Schwarz 于 1880 年提出。

平移（旋转），这直观上对应于第 4.5 节讨论的 $SO(2)$ 规范变换带来的歧义。[60]对于固定规范，可以定义对局部方向敏感的各向异性拉普拉斯算子，它相当于改变度量或权重 w_{uv}。Andreux et al.（2014）、Boscaini et al.（2016b）使用这种构造设计形状描述符，Boscaini et al.（2016a）将其用于早期网格几何深度学习架构。



平面上具有径向对称性的拉普拉斯滤波器示例。

网格上的谱分析 将拉普拉斯矩阵对角化的正交特征向量 $\Phi = (\phi_1, \dots, \phi_n)$（其中 $\Delta = \Phi\Lambda\Phi^\top$，$\Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ 是拉普拉斯特征值的对角矩阵），可用作傅里叶基的非欧几里得类比，允许通过相应傅里叶变换的乘积在网格上执行谱卷积：

$$\mathbf{X} \star \theta = \Phi \operatorname{diag}(\Phi^\top \theta)(\Phi^\top \mathbf{X}) = \Phi \operatorname{diag}(\widehat{\theta})\widehat{\mathbf{X}},$$

其中滤波器 $\widehat{\theta}$ 直接在傅里叶域中设计。再次强调，这一公式没有任何网格特有之处，也可使用一般（无向）图的拉普拉斯矩阵。[61]利用这一定义的谱卷积将 CNN 推广到图是很自然的想法；事实上，本文作者之一 Bruna et al.（2013）曾这样做。然而，非欧几里得傅里叶变换似乎对底层网格或图的微小扰动极其敏感（见第 4.4 节图 12），因此只适合处理固定定义域上的不同信号，而不适合希望跨不同定义域泛化的情形。不幸的是，许多计算机图形学和视觉问题属于后者：在一组三维形状（网格）上训练神经网络，在另一组上测试，使得基于傅里叶变换的方法并不适宜。

如第 4.4 节所述，更可取的是使用式 (18) 所示形式的谱滤波器，将某

[60]基于拉普拉斯算子的滤波器是各向同性的；在平面上，此类滤波器具有径向对称性。

[61]假定图无向很重要：此时拉普拉斯矩阵是对称的，并具有正交特征向量。

个传递函数 $\widehat{p}(\lambda)$ 作用于拉普拉斯矩阵：

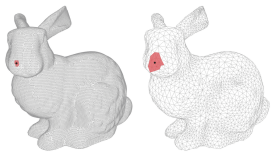
$$\widehat{p}(\Delta)\mathbf{X} = \Phi\widehat{p}(\Lambda)\Phi^\top\mathbf{X} = \Phi\,\mathrm{diag}(\widehat{p}(\lambda_1),\dots,\widehat{p}(\lambda_n))\widehat{\mathbf{X}}.$$

当 $\widehat{p}$ 可用矩阵—向量乘积表示时，可以完全避免对 $n\times n$ 矩阵 Δ 进行特征分解。[62]例如，Defferrard et al.（2016）使用 r 阶多项式作为滤波器函数：

$$\widehat{p}(\Delta)\mathbf{X} = \sum_{k=0}^{r}\alpha_k\Delta^k\mathbf{X} = \alpha_0\mathbf{X} + \alpha_1\Delta\mathbf{X} + \cdots + \alpha_r\Delta^r\mathbf{X},$$

相当于用 $n\times n$ 拉普拉斯矩阵与 $n\times d$ 特征矩阵 $\mathbf{X}$ 相乘 r 次。由于拉普拉斯矩阵通常是稀疏的（具有 $O(|\mathcal{E}|)$ 个非零元素），这个操作的复杂度较低，为 $O(|\mathcal{E}|dr)\sim O(|\mathcal{E}|)$。[63]此外，由于拉普拉斯算子是局部的，$r$ 阶多项式滤波器局域在 r 跳邻域中。

然而，对于网格，这一性质恰恰带来不利之处：滤波器的实际支撑（即其覆盖半径）依赖网格分辨率。需要牢记，网格来自某个底层连续曲面的离散化，而两个不同网格 $\mathcal{T}$ 和 $\mathcal{T}'$ 可能表示同一个对象。对于较细的网格，可能需要比较粗网格更大的邻域，因此需要更高阶数 r 的滤波器。



不同分辨率网格上的两跳邻域。

因此，在计算机图形学应用中更常使用有理滤波器，因为它们与分辨率无关。定义此类滤波器有许多方法（见例如 Patanè（2020）），最常见的是某个有理函数的多项式，例如 $(\lambda-1)/(\lambda+1)$。更一般地，也可以使用复函数，例如将实轴映到复平面单位圆上的 Cayley 变换 $(\lambda-i)/(\lambda+i)$。[64]Levie et

[62]一般情况下，特征分解的复杂度为 $O(n^3)$。

[63]网格是近似正则图，每个节点有 $O(1)$ 个邻居，因而 Δ 中有 $O(n)$ 个非零元素。

[64]Cayley 变换是 Möbius 变换的特例。将其应用于拉普拉斯算子（正半定矩阵）时，它将非负特征值映到复平面的半圆上。

al. (2018) 使用表示为 Cayley 多项式的谱滤波器：它们是具有复系数 $\alpha_l \in \mathbb{C}$ 的实有理函数，

$$\widehat{p}(\lambda) = \mathrm{Re}\left(\sum_{l=0}^{r} \alpha_l \left(\frac{\lambda - i}{\lambda + i}\right)^l\right).$$

应用于矩阵时，计算 Cayley 多项式需要矩阵求逆：

$$\widehat{p}(\Delta) = \mathrm{Re}\left(\sum_{l=0}^{r} \alpha_l (\Delta - iI)^l (\Delta + iI)^{-l}\right),$$

它可以用线性复杂度近似计算。不同于多项式滤波器，有理滤波器没有局部支撑，但具有指数衰减（Levie et al.，2018）。[65]与直接计算傅里叶变换的一个关键区别是，多项式和有理滤波器在底层图或网格的近似等距形变下是稳定的；例如 Levie et al.（2018，2019）、Gama et al.（2020）和 Kenlay et al.（2021）给出了多种此类结果。

作为算子的网格与函数映射 函数映射范式建议将网格视为算子。我们将说明，这允许利用网格的额外结构获得更有意思的不变性。为讨论方便，假设网格 $\mathcal{T}$ 建立在具有坐标 $\mathbf{X}$ 的嵌入节点上。如果构造一个内禀算子（如拉普拉斯算子），可以证明它完全编码网格结构，并可以恢复网格（至其等距嵌入为止，见 Zeng et al.（2012））。对于其他一些算子也有同样结论（例如 Boscaini et al.（2015）、Corman et al.（2017）、Chern et al.（2018）），因此我们将采用一般算子或 $n \times n$ 矩阵 $Q(\mathcal{T}, \mathbf{X})$ 表示网格。

从这一观点看，第 4.1 节关于学习形式为 $f(\mathbf{X}, \mathcal{T})$ 的函数的讨论，可以改写为学习形式为 $f(Q)$ 的函数。与图和集合类似，网格节点也没有标准顺序，即网格上的函数必须满足置换不变或等变条件：

$$f(Q) = f(PQP^\top),$$
$$P\mathbf{F}(Q) = \mathbf{F}(PQP^\top),$$

对任意置换矩阵 P 成立。然而，与一般图相比，现在有了更多结构：我们可以假定网格来自某个底层连续曲面 Ω 的离散化。因此，可能存在另一个具有

[65]在信号处理中，多项式滤波器称为有限冲激响应（FIR），而有理滤波器称为无限冲激响应（IIR）。

n' 个节点和坐标 $\mathbf{X}'$ 的网格 $\mathcal{T}' = (\mathcal{V}', \mathcal{E}', \mathcal{F}')$，与 $\mathcal{T}$ 表示同一个对象 Ω。重要的是，网格 $\mathcal{T}$ 和 $\mathcal{T}'$ 可以有不同的连接结构，甚至节点数不同（$n' \neq n$）。因此，不能把它们视为仅有节点重新排序的同构图，也不能将置换矩阵 P 看作二者之间的对应。

Ovsjanikov et al.（2012）引入函数映射，将对应概念推广到这类情形：用函数之间的对应（映射 $C : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega')$）替代两个定义域之间点的对应（映射 $\eta : \Omega \to \Omega'$），见图 13。函数映射是线性算子 C，表示为 $n' \times n$ 矩阵，建立各定义域上信号 x' 和 x 之间的对应关系 $x' = Cx$。[66]Rustamov et al.（2013）表明，为保证映射保持面积，函数映射必须正交，即 $C^\top C = I$，也就是说，它是正交群的元素 $C \in O(n)$。此时可以用 $C^{-1} = C^\top$ 求逆映射。

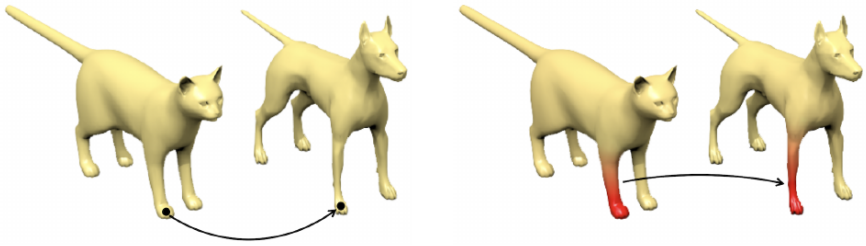


图 13: 逐点映射（左）与函数映射（右）。

函数映射还建立了网格的算子表示之间的关系：

$$Q' = CQC^\top, \qquad Q = C^\top Q' C,$$

其解释如下：给定 $\mathcal{T}$ 的算子表示 Q 和函数映射 C，可以先将信号从 $\mathcal{T}'$ 映到 $\mathcal{T}$（使用 $C^\top$），应用算子 Q，再映回 $\mathcal{T}'$（使用 C），从而构造 $\mathcal{T}'$ 的表示 Q'。[67]这引出更一般的网格重网格化不变（或等变）函数类，满足

$$f(Q) = f(CQC^\top) = f(Q'),$$
$$C\mathbf{F}(Q) = \mathbf{F}(CQC^\top) = \mathbf{F}(Q'),$$

[66]多数情况下，函数映射在谱域中实现为傅里叶系数之间的 $k \times k$ 映射 $\widehat{C}$：$x' = \Phi' \widehat{C} \Phi^\top x$，其中 Φ 和 Φ' 分别是（截断的）拉普拉斯特征基组成的 $n \times k$ 和 $n' \times k$ 矩阵，且 $k \ll n, n'$。

[67]注意这些操作从右向左读。

对任意 $C \in O(n)$ 成立。容易看出，之前的置换不变和等变情形是一个特例，可看作仅改变节点顺序的平凡重网格化。[68]

Wang et al.（2019a）表明，给定算子 $Q = V\Lambda V^\top$ 的特征分解，任何重网格化不变（或等变）函数都可写为 $f(Q) = f(\Lambda)$ 和 $\mathbf{F}(Q) = V\mathbf{F}(\Lambda)$；换言之，重网格化不变函数只涉及 Q 的谱。实际上，拉普拉斯特征值的函数已被证明对曲面离散化和扰动具有鲁棒性，这解释了基于拉普拉斯算子的谱构造在计算机图形学及图深度学习中的流行（Defferrard et al.，2016；Levie et al.，2018）。由于这一结果针对一般算子 Q，除了无处不在的拉普拉斯算子外，还有多种选择；值得注意的例子包括 Dirac 算子（Liu et al.，2017；Kostrikov et al.，2018）或 Steklov 算子（Wang et al.，2018），以及可学习的参数算子（Wang et al.，2019a）。

[68] 这来自置换矩阵的正交性：$P^\top P = I$。

第五章　几何深度学习模型

在充分研究了几何深度学习蓝图的各种实例（针对不同定义域、对称群和局域性概念）之后，我们可以讨论如何通过实施这些规定得到一些最流行的深度学习架构。

我们的叙述同样不严格按照一般性排列。首先介绍三种架构，其实现几乎可以直接从前面的讨论得到：卷积神经网络（CNN）、群等变 CNN 和图神经网络（GNN）。

随后我们更仔细地考察预先不知道图结构（即无序集合）时的 GNN 变体，并在讨论中将流行的 Deep Sets 和 Transformer 架构描述为 GNN 的实例。

在讨论几何图和网格之后，我们先介绍等变消息传递网络，它将显式几何对称性引入 GNN 计算。接着展示测地线和规范对称性理论如何在深度学习中实现，从而得到一族内禀网格 CNN，包括测地 CNN、MoNet 和规范等变网格 CNN。

最后，我们从时间角度回看网格定义域。这一讨论会引出循环神经网络（RNN）。我们将展示 RNN 在时间网格上具有平移等变性的一种方式，同时研究其对时间规整变换的稳定性。这一性质对于恰当处理长程依赖非常理想；强制模型类别对此类变换不变，恰好得到门控 RNN 类，包括常用的 LSTM 或 GRU 模型。

虽然我们希望上述内容概述写作时使用的大多数关键深度学习架构，但也清楚每天都有新神经网络实例被提出。因此，我们并不试图涵盖所有可能架构，而希望以下各节提供足够的示例，使读者能够通过不变性和对称性的视角轻松归类未来的几何深度学习进展。

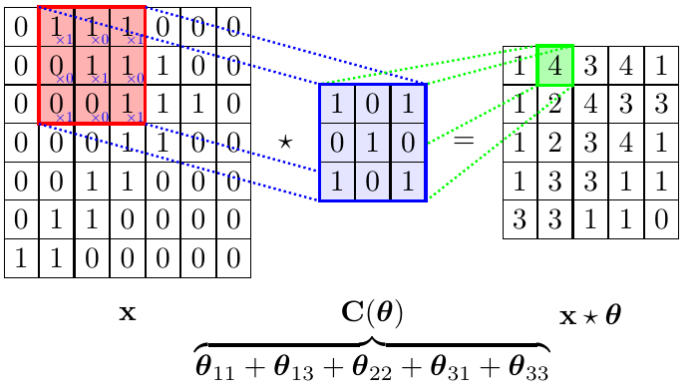


图 14: 用滤波器 $C(\theta)$ 对图像 x 作卷积的过程。滤波器参数 θ 可以表示为生成元 θ_{vw} 的线性组合。

5.1 卷积神经网络

卷积神经网络或许是遵循第 3.5 节所概述几何深度学习蓝图的最早、最著名的深度学习架构例子。在第 4.2 节，我们完整刻画了线性局部平移等变算子类，它们由具有局域滤波器 θ 的卷积 $C(\theta)x = x \star \theta$ 给出。[1]先关注标量值（“单通道”或“灰度”）离散图像，其中定义域为网格 $\Omega = [H] \times [W]$，$u = (u_1, u_2)$，且 $x \in \mathcal{X}(\Omega, \mathbb{R})$。

任何支撑紧致、大小为 $H^f \times W^f$ 的滤波器所定义的卷积，都可以写成生成元 $\theta_{1,1}, \dots, \theta_{H^f, W^f}$ 的线性组合，例如单位峰 $\theta_{vw}(u_1, u_2) = \delta(u_1 - v, u_2 - w)$。因此，任意局部线性等变映射都可表示为[2]

$$\mathbf{F}(x) = \sum_{v=1}^{H^f} \sum_{w=1}^{W^f} \alpha_{vw} C(\theta_{vw}) x, \tag{26}$$

它在坐标下对应熟悉的二维卷积（图 14 给出概览）：

$$\mathbf{F}(x)_{uv} = \sum_{a=1}^{H^f} \sum_{b=1}^{W^f} \alpha_{ab} x_{u+a, v+b}. \tag{27}$$

[1]回顾一下，$C(\theta)$ 是参数为 θ 的循环矩阵。

[2]我们通常把 x 和 θ_{vw} 想象为二维矩阵，但在此式中，它们的两个坐标维度都被展平成一维，因此 x 是向量，$C(\theta_{vw})$ 是矩阵。

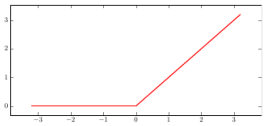
也可以选择其他基 θ_{vw}，它们会产生等价操作（所需的 α_{vw} 可能不同）。一个常见例子是方向导数 $\theta_{vw}(u_1,u_2)=\delta(u_1,u_2)-\delta(u_1-v,u_2-w)$，其中 $(v,w)\neq(0,0)$，再加上局部平均 $\theta_0(u_1,u_2)=1/(H^fW^f)$。事实上，方向导数可以视为网格特有的图上扩散过程类比；如果将每个像素视为与网格中直接相邻像素连接的节点，便可得到这种类比。

当标量输入通道被多个通道替代时（例如 RGB 颜色，或更一般的任意数量特征图），卷积滤波器变为卷积张量，表达输入特征到输出特征图的任意线性组合。在坐标下可以表示为

$$\mathbf{F}(x)_{uvj}=\sum_{a=1}^{H^f}\sum_{b=1}^{W^f}\sum_{c=1}^{M}\alpha_{jabc}x_{u+a,v+b,c},\qquad j\in[N], \tag{28}$$

其中 M 和 N 分别是输入和输出通道数。这一基本操作涵盖广泛的神经网络架构；如下一节将展示，它们对计算机视觉、信号处理及其他众多领域产生了深远影响。这里我们不剖析 CNN 种类繁多的架构变体，而着重介绍使其获得广泛应用的若干关键创新。

高效多尺度计算 如一般对称性的 GDL 模板中所述，从卷积算子 $\mathbf{F}$ 提取平移不变特征需要一个非线性步骤。卷积特征通过非线性激活函数 σ 处理，该函数逐元素作用于输入，即 $\sigma:\mathcal{X}(\Omega)\to\mathcal{X}(\Omega)$，$(\sigma(x))(u)=\sigma(x(u))$。写作时最流行的例子或许是修正线性单元（ReLU）：$\sigma(x)=\max(x,0)$。这种非线性有效地对信号作整流，将其能量推向较低频率，并通过迭代这一构造实现跨尺度高阶相互作用的计算。[3]



ReLU 函数示意。

[3]ReLU 常被视为“现代”架构选择，但早已用于 Neocognitron（Fukushima and Miyake, 1982）。整流等价于解调原理；解调作为许多传输协议（例如 FM 广播）的基础，在电气工程中十分重要，在神经元活动模型中也占有重要地位。

早在 Fukushima and Miyake（1982）及 LeCun et al.（1998）的工作中，CNN 和类似架构就具有多尺度结构：每个卷积层 (28) 后都进行网格粗化 $P : \mathcal{X}(\Omega) \to \mathcal{X}(\Omega')$，其中 Ω' 的分辨率低于 Ω。这样可以得到有效感受野不断增大的多尺度滤波器，同时每个尺度的参数数量保持不变。可以使用若干信号粗化策略 P（称为池化）；最常见的是先应用低通抗混叠滤波器（例如局部平均）再对网格下采样，或者使用非线性最大池化。

总之，一个“普通”CNN 层可以表示为几何深度学习蓝图中已引入的基本对象的复合：

$$h = P(\sigma(\mathbf{F}(x))), \tag{29}$$

即等变线性层 $\mathbf{F}$、粗化操作 P 和非线性 σ。CNN 内也可以执行平移不变的全局池化操作。直观地说，每个像素在经过若干卷积后总结其周围的图像块，并提出图像的最终表示；最终选择由对这些提案的某种聚合引导。一个常见选择是平均函数，因为无论图像大小如何，其输出都会保持相近量级（Springenberg et al.，2014）。[4]遵循这一 CNN 蓝图的著名例子（其中一些将在下文讨论）见图 15。

深层网络与残差网络

最简单形式的 CNN 架构由超参数 $(H_k^f, W_k^f, N_k, p_k)_{k \le K}$ 指定，其中 $M_{k+1} = N_k$，且 $p_k = 0, 1$ 表示是否进行网格粗化。虽然所有这些超参数在实践中都很重要，一个尤其重要的问题是理解深度 K 在 CNN 架构中的作用，以及选择这一关键超参数时涉及的根本权衡，尤其是它与滤波器大小 (H_k^f, W_k^f) 的关系。

虽然该问题的严格答案仍不明朗，近年来积累的越来越多实证证据表明，更深（较大 K）但更窄（较小 (H_k^f, W_k^f)）的模型具有有利的权衡。在此背景下，He et al.（2016）的关键见解是重新参数化每个卷积层，使其对

[4]仅由本段所述操作构成的 CNN 常被称为“全卷积”。相比之下，许多 CNN 在应用足够多的等变和粗化层之后，将图像沿空间轴展平，再传给 MLP 分类器；这会失去平移不变性。

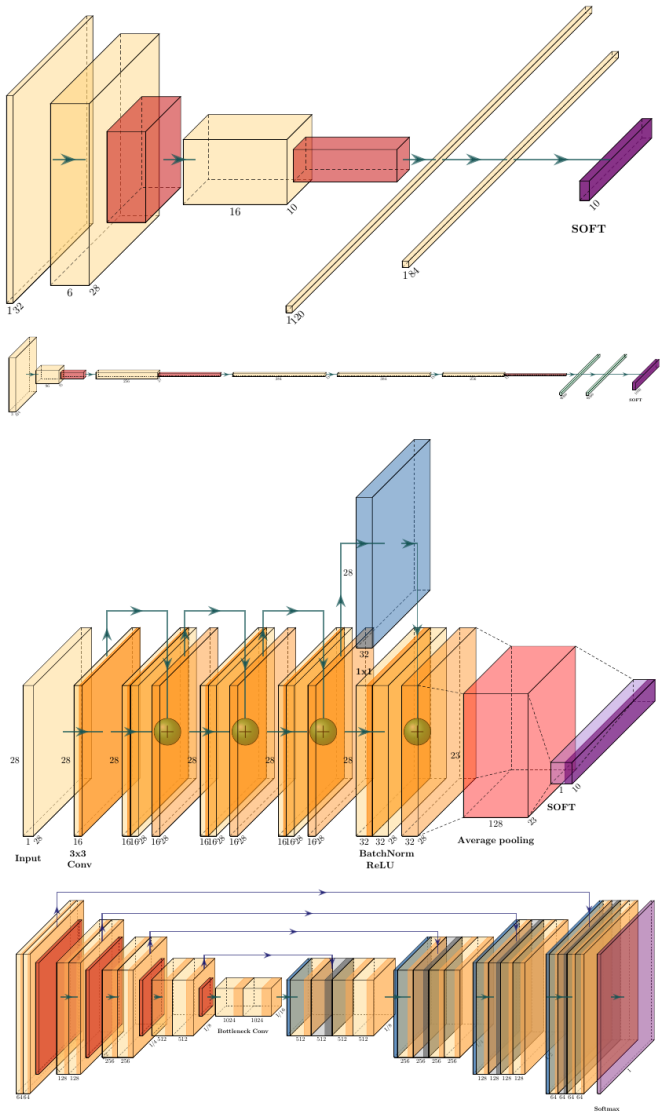


图 15: 著名 CNN 架构示例。从上到下：LeNet（LeCun et al., 1998）、AlexNet（Krizhevsky et al., 2012）、ResNet（He et al., 2016）和 U-Net（Ronneberger et al., 2015）。使用 PlotNeuralNet 软件包绘制（Iqbal，2018）。

先前特征的扰动而非一般非线性变换建模：[5]

$$h = P\big(x + \sigma(\mathbf{F}(x))\big). \tag{30}$$

所得残差网络相对于先前表述具有若干关键优势。其本质在于，残差参数化与深层网络是由常微分方程（ODE）建模的底层连续动力系统的离散化这一观点相一致。关键的是，通过对速度建模来学习动力系统，事实证明比直接学习其位置容易得多。[6]在我们的学习设定中，这转化为具有更有利几何性质的优化景观，使得可以训练比以前深得多的架构。

如未来工作将讨论的，使用深度神经网络学习定义了一个非凸优化问题，在某些简化情形下可以用梯度下降法高效求解。ResNet 参数化的关键优势已在简单情景中得到严格分析（Hardt and Ma，2016），仍是活跃的理论研究领域。最后，Neural ODE（Chen et al.，2018）是一种近期流行架构，它通过直接学习 ODE $\dot{x} = \sigma(\mathbf{F}(x))$ 的参数并使用标准数值积分，将与 ODE 的类比推得更远。

归一化 另一项显著提升 CNN 实证性能的重要算法创新是归一化概念。在早期神经活动模型中，人们假设神经元执行某种局部“增益控制”，其中层系数 x_k 被替换为 $\widetilde{x}_k = \sigma_k^{-1}(x_k - \mu_k)$。这里 μ_k 和 σ_k 分别编码 x_k 的一阶和二阶矩信息；它们既可以全局计算，也可以局部计算。

在深度学习中，这一原理通过批归一化层（Ioffe and Szegedy，2015）得到广泛采用，随后出现了若干变体（Ba et al.，2016；Salimans and Kingma，2016；Ulyanov et al.，2016；Cooijmans et al.，2016；Wu and He，2018）。[7]尽管已有一些尝试通过条件更好的优化景观严格解释归一化的好处（Santurkar et al.，2018），截至写作时，仍缺少能够提供指导原则的一般理论。

数据增强 虽然 CNN 编码了与平移不变性和尺度分离有关的几何先验，但它们没有显式考虑其他已知的语义保持变换，例如光照或颜色变化、小幅旋

[5]从历史上看，ResNet 模型之前已有 highway networks（Srivastava et al.，2015），它们允许使用更一般的门控机制来控制残差信息流。

[6]此时 ResNet 对 ODE $\dot{x} = \sigma(\mathbf{F}(x))$ 执行前向 Euler 离散化。

[7]在批归一化出现之前，神经网络激活值的归一化就已受到关注，参见例如 Lyu and Simoncelli（2008）。

转及伸缩。一种仅需最小架构改动即可纳入这些先验的实用方法是数据增强：手动对输入图像执行上述变换并将结果加入训练集。

数据增强在经验上取得成功并被广泛使用——不仅用于训练最先进的视觉架构，也推动了自监督和因果表示学习的若干进展（Chen et al.，2020；Grill et al.，2020；Mitrovic et al.，2020）。然而，可以证明它在样本复杂度方面不是最优的（Mei et al.，2021）；更高效的策略是考虑具有更丰富不变群的架构，这将是下一节的讨论内容。

5.2 群等变 CNN

如第 4.3 节所述，可以将卷积操作从欧几里得空间上的信号推广到由群 $\mathfrak{G}$ 作用的任意齐性空间 Ω 上的信号。[8]类比欧几里得卷积中用平移后的滤波器匹配信号，群卷积的思想是利用群作用在定义域上移动滤波器，例如通过旋转和平移。凭借群作用的传递性，我们可以将滤波器移到 Ω 上任意位置。本节将讨论群卷积这一一般思想的若干具体例子，包括实现方面和架构选择。

离散群卷积 首先考虑定义域 Ω 和群 $\mathfrak{G}$ 都离散的情形。第一个例子是表示为三维网格上信号的医学体图像，它具有离散平移和旋转对称性。定义域是三维立方网格 $\Omega = \mathbb{Z}^3$，图像（例如 MRI 或 CT 三维扫描）建模为函数 $x : \mathbb{Z}^3 \to \mathbb{R}$，即 $x \in \mathcal{X}(\Omega)$。虽然实际图像的支撑是有限长方体 $[W] \times [H] \times [D] \subset \mathbb{Z}^3$，我们更愿意把它们视为 $\mathbb{Z}^3$ 上经过适当零填充的函数。作为对称性，我们考虑 $\mathbb{Z}^3$ 上保持距离和定向的变换群 $\mathfrak{G} = \mathbb{Z}^3 \rtimes O_h$。该群由平移（$\mathbb{Z}^3$）以及绕三个坐标轴各旋转 90 度所生成的离散旋转 O_h 构成（见图 16）。

第二个例子是由 C、G、A、T 四个字母组成的 DNA 序列。序列可以表示为一维网格 $\Omega = \mathbb{Z}$ 上的信号 $x : \mathbb{Z} \to \mathbb{R}^4$，其中每个字母在 $\mathbb{R}^4$ 中以独热编码表示。[9]网格上自然具有离散一维平移对称性，但 DNA 序列还有一种

[8]回顾一下，齐性空间是赋有传递群作用的集合 Ω，即对任意 $u, v \in \Omega$，存在 $\mathfrak{g} \in \mathfrak{G}$ 使 $\mathfrak{g}.u = v$。

[9]DNA 是由称为核苷酸的四种重复单元（胞嘧啶、鸟嘌呤、腺嘌呤和胸腺嘧啶）组成的

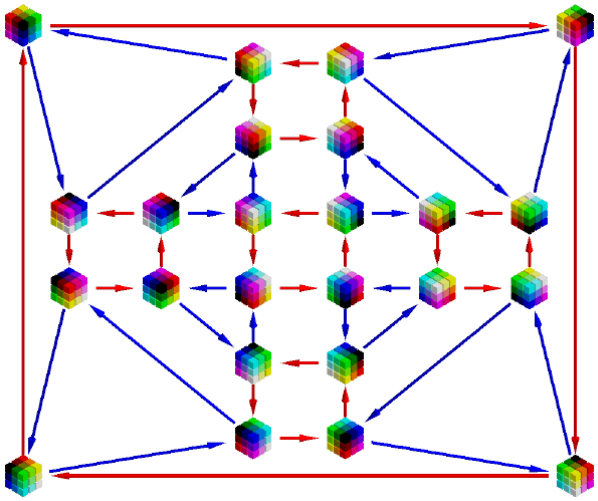
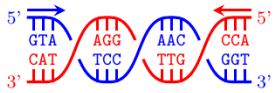


图 16: 一个 3×3 滤波器经离散旋转群 O_h 的全部 24 个元素旋转。该群由绕竖直轴 90 度旋转（红色箭头）与绕对角轴 120 度旋转（蓝色箭头）生成。

有趣的对称性。它源于 DNA 以双螺旋形式存在，以及细胞分子机制读取它的方式。双螺旋的每条链都以所谓的 $5'$ 端开始、以 $3'$ 端结束，一条链的 $5'$ 端与另一条链的 $3'$ 端互补；换言之，两条链方向相反。由于 DNA 分子总是从 $5'$ 端开始读取，但我们不知道读取的是哪一条链，因此序列 ACCCTGG 与将序列反向并把每个字母替换为其互补字母后得到的 CCAGGGT 等价。这称为字母序列的反向互补对称性。



DNA 双螺旋结构示意，两条链分别为蓝色和红色。螺旋中的序列相互互补，并沿相反方向（从 $5'$ 到 $3'$）读取。

因此，二元群 $\mathbb{Z}_2 = \{0, 1\}$ 分别对应恒等变换 0 和反向互补变换 1（复合满足 $1 + 1 = 0 \bmod 2$）。完整的群结合了平移与反向互补变换。在我们的

生物聚合物；两条链互相盘绕成双螺旋，每个核苷酸都与互补核苷酸相对（碱基对 A/T 和 C/G）。

情形中，第 4.3 节定义的群卷积 (14) 为

$$(x \star \theta)(\mathfrak{g}) = \sum_{u \in \Omega} x_u \rho(\mathfrak{g}) \theta_u, \tag{31}$$

即（单通道）输入信号 x 与经 $\mathfrak{g} \in \mathfrak{G}$ 通过 $\rho(\mathfrak{g})\theta_u = \theta_{\mathfrak{g}^{-1}u}$ 变换的滤波器 θ 的内积；输出 $x \star \theta$ 是 $\mathfrak{G}$ 上的函数。注意，由于 Ω 离散，我们将式 (14) 中的积分换成了求和。

变换加卷积的方法 我们将说明，群卷积可以分两步实现：滤波器变换和标准平移卷积。滤波器变换步骤创建基本滤波器经旋转（或反向互补变换）的副本；平移卷积则与标准 CNN 中相同，因此可以在 GPU 等硬件上高效计算。为此注意，在两个例子中都可以将一般变换 $\mathfrak{g} \in \mathfrak{G}$ 写为变换 $\mathfrak{h} \in \mathfrak{H}$（例如旋转或反向互补变换）后接平移 $\mathfrak{k} \in \mathbb{Z}^d$，即 $\mathfrak{g} = \mathfrak{k}\mathfrak{h}$；并置表示群元素的复合。根据群表示的性质，$\rho(\mathfrak{g}) = \rho(\mathfrak{k}\mathfrak{h}) = \rho(\mathfrak{k})\rho(\mathfrak{h})$。因此，

$$\begin{aligned}(x \star \theta)(\mathfrak{k}\mathfrak{h}) &= \sum_{u \in \Omega} x_u \rho(\mathfrak{k})\rho(\mathfrak{h})\theta_u \\ &= \sum_{u \in \Omega} x_u (\rho(\mathfrak{h})\theta)_{u-\mathfrak{k}}.\end{aligned} \tag{32}$$

最后一式正是信号 x 与变换后滤波器 $\rho(\mathfrak{h})\theta$ 的标准（平面欧几里得）卷积。因此，为实现这些群的群卷积，我们取标准滤波器 θ，对每个 $\mathfrak{h} \in \mathfrak{H}$ 创建变换后的副本 $\theta_{\mathfrak{h}} = \rho(\mathfrak{h})\theta$（例如每个旋转 $\mathfrak{h} \in O_h$ 或 DNA 反向互补对称性 $\mathfrak{h} \in \mathbb{Z}_2$），再将 x 与每个滤波器卷积：$(x \star \theta)(\mathfrak{k}\mathfrak{h}) = (x \star \theta_{\mathfrak{h}})(\mathfrak{k})$。两个例子中的对称性都通过置换滤波器系数来作用于滤波器，如图 16 中的离散旋转所示。因此，这些操作可以使用预先计算的索引，通过索引操作高效实现。

虽然我们将群卷积 $x \star \theta$ 输出的特征图定义为 $\mathfrak{G}$ 上的函数，但由于可以将 $\mathfrak{g}$ 分解为 $\mathfrak{h}$ 和 $\mathfrak{k}$，也可以将其视为一叠欧几里得特征图（有时称为方向通道），每个滤波器变换 / 方向 $\mathfrak{k}$ 对应一个特征图。例如，在第一个例子中，我们会为每个滤波器旋转（图 16 中每个节点）关联一个特征图，它通过与旋转后的滤波器作传统平移意义下的卷积得到。这些特征图因此仍可存储为 $W \times H \times C$ 数组，其中通道数 C 等于独立滤波器数量乘以变换 $\mathfrak{h} \in \mathfrak{H}$（例如旋转）的数量。

如第 4.3 节所示，群卷积是等变的：$(\rho(\mathfrak{g})x) \star \theta = \rho(\mathfrak{g})(x \star \theta)$。对于方向通道，这意味着在 $\mathfrak{h}$ 的作用下，每个方向通道都会变换，而方向通道本身也会被置换。例如，如果每个方向通道对应图 16 中一个变换，并施加绕 z 轴 90 度旋转（对应红色箭头），特征图就会按红色箭头所示方式置换。这一描述清楚表明群卷积神经网络与传统 CNN 非常相似。因此，第 5.1 节讨论的许多网络设计模式，例如残差网络，也可以用于群卷积。

傅里叶域中的球面 CNN 对于第 4.3 节见过的球面连续对称群，可以使用适当的傅里叶变换在谱域中实现卷积。回顾一下，S^2 上的卷积是 $SO(3)$ 上的函数，因此为实现多层球面 CNN，需要在两个定义域上都定义傅里叶变换。球谐函数是二维球面上的正交基，类似于复指数构成的经典傅里叶基。在特殊正交群上，傅里叶基称为 Wigner D 函数。在两种情况下，傅里叶变换（系数）都通过与基函数取内积计算，且存在卷积定理的类比：可以在傅里叶域通过傅里叶变换的逐元素乘积计算卷积。此外，也存在在 S^2 和 $SO(3)$ 上高效计算傅里叶变换的类 FFT 算法。更多细节请参阅 Cohen et al.（2018）。

5.3 图神经网络

图神经网络（GNN）是几何深度学习蓝图在图上的实现，它利用置换群的性质。GNN 是目前存在的最一般的深度学习架构类之一；如本文将看到的，大多数其他深度学习架构都可以理解为具有额外几何结构的 GNN 特例。

按照第 4.1 节的讨论，图由邻接矩阵 A 和节点特征 $\mathbf{X}$ 指定。我们将研究作为置换等变函数 $\mathbf{F}(\mathbf{X}, A)$ 的 GNN 架构；这些函数通过在局部邻域上应用共享的置换不变函数 $\phi(\mathbf{x}_u, \mathbf{X}_{\mathcal{N}_u})$ 构造。在不同情境下，这一局部函数 ϕ 可称为“扩散”“传播”或“消息传递”，而这种 $\mathbf{F}$ 的整体计算称为“GNN 层”。

截至写作时，GNN 层的设计和研究是深度学习最活跃的领域之一，因此很难把握全貌。幸运的是，我们发现绝大多数文献可以从仅三种“类型”的 GNN 层推导出来（图 17），下面将介绍它们。这些类型决定 ϕ 对邻域特

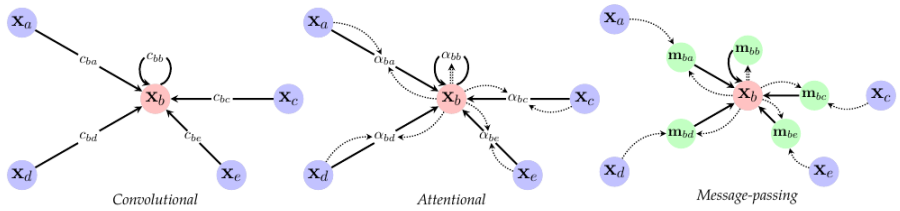


图 17: 三类 GNN 层 g 的数据流示意，使用图 10 中节点 b 的邻域说明。从左到右：卷积型，将发送节点的特征乘以常数 c_{uv}；注意力型，通过接收节点对发送节点的注意力机制隐式计算乘数 $\alpha_{uv} = a(\mathbf{x}_u, \mathbf{x}_v)$；消息传递型，根据发送节点和接收节点计算向量消息 $\mathbf{m}_{uv} = \psi(\mathbf{x}_u, \mathbf{x}_v)$。

征变换的程度，从而允许以不同复杂度对图中的相互作用建模。

在三种类型中，都通过用置换不变函数 $\bigoplus$ 聚合 $\mathbf{X}_{\mathcal{N}_u}$ 中的特征（可能先通过某个函数 ψ 变换），再通过某个函数 ϕ 更新节点 u 的特征，来保证置换不变性。通常 ψ 和 ϕ 是可学习的，而 $\bigoplus$ 实现为求和、平均或最大值等非参数操作；但也可以例如使用循环神经网络构造它（Murphy et al., 2018）。[10]

在卷积型（Kipf and Welling, 2016a; Defferrard et al., 2016; Wu et al., 2019）中，以固定权重直接聚合邻域节点的特征：

$$\mathbf{h}_u = \phi\left(\mathbf{x}_u, \bigoplus_{v \in \mathcal{N}_u} c_{uv}\psi(\mathbf{x}_v)\right). \tag{33}$$

这里 c_{uv} 指定节点 v 对节点 u 表示的重要性；它是常数，通常直接依赖于表示图结构的 A 的元素。注意，当聚合算子 $\bigoplus$ 选择求和时，可以将其视为线性扩散或位置相关的线性滤波，即卷积的推广。特别是第 4.4 和 4.6 节见过的谱滤波器属于此类，因为它们相当于将固定局部算子（例如拉普拉斯矩阵）应用于逐节点信号。[11]

在注意力型（Veličković et al., 2018; Monti et al., 2017; Zhang et al.,

[10] 最常见的是 ψ 和 ϕ 为带激活函数的可学习仿射变换，例如 $\psi(\mathbf{x}) = W\mathbf{x} + \mathbf{b}$、$\phi(\mathbf{x}, \mathbf{z}) = \sigma(W\mathbf{x} + U\mathbf{z} + \mathbf{b})$，其中 $W, U, \mathbf{b}$ 是可学习参数，σ 是修正线性单元等激活函数。向 ϕ 额外输入 $\mathbf{x}_u$ 构成一个可选的跳跃连接，通常非常有用。

[11] 值得注意的是，这一类型并不能表达每一种卷积型 GNN 层（这里卷积型指与图结构交换），但涵盖了实践中提出的大多数此类方法。我们将在未来工作中提供详细讨论和扩展。

2018）中，相互作用是隐式的：

$$\mathbf{h}_u = \phi\left(\mathbf{x}_u, \bigoplus_{v\in\mathcal{N}_u} a(\mathbf{x}_u, \mathbf{x}_v)\psi(\mathbf{x}_v)\right). \tag{34}$$

其中 a 是可学习的自注意力机制，隐式计算重要性系数 $\alpha_{uv} = a(\mathbf{x}_u, \mathbf{x}_v)$；这些系数通常在所有邻居上进行 softmax 归一化。当 $\bigoplus$ 为求和时，聚合仍是邻域节点特征的线性组合，但权重现在依赖于特征。

最后，消息传递型（Gilmer et al.，2017；Battaglia et al.，2018）相当于沿边计算任意向量（“消息”）：

$$\mathbf{h}_u = \phi\left(\mathbf{x}_u, \bigoplus_{v\in\mathcal{N}_u} \psi(\mathbf{x}_u, \mathbf{x}_v)\right). \tag{35}$$

其中 ψ 是可学习的消息函数，计算 v 发送给 u 的向量；聚合可以视为图上的一种消息传递形式。

重要的一点是这些方法之间的表达包含关系：卷积 $\subseteq$ 注意力 $\subseteq$ 消息传递。事实上，注意力 GNN 可以通过实现为查找表的注意力机制 $a(\mathbf{x}_u, \mathbf{x}_v) = c_{uv}$ 表示卷积 GNN；卷积和注意力 GNN 又都是消息传递的特例，其中消息仅是发送节点的特征：卷积 GNN 为 $\psi(\mathbf{x}_u, \mathbf{x}_v) = c_{uv}\psi(\mathbf{x}_v)$，注意力 GNN 为 $\psi(\mathbf{x}_u, \mathbf{x}_v) = a(\mathbf{x}_u, \mathbf{x}_v)\psi(\mathbf{x}_v)$。

这并不意味着消息传递 GNN 总是最有用的变体；由于它们需要沿边计算向量值消息，通常更难训练，并需要难以处理的大量内存。此外，在许多自然出现的图上，边编码了下游类别的相似性，即边 (u, v) 意味着 u 和 v 可能具有相同输出。对于这类通常称为同配图的图，跨邻域的卷积聚合无论在正则化还是可扩展性方面往往都是好得多的选择。注意力 GNN 提供一种“中间地带”：它们允许对邻域内复杂相互作用建模，同时只沿边计算标量值，因而比消息传递更易扩展。

这里给出的“三种类型”分类力求简洁，不可避免地忽略了 GNN 模型中大量细节、见解、推广和历史背景。值得注意的是，它不包括基于 Weisfeiler–Lehman 层次的高维 GNN，也不包括依赖显式计算图傅里叶变换的谱 GNN。

5.4 Deep Sets、Transformer 与潜在图推断

我们以对无序集合表示学习的置换等变神经网络架构的讨论结束对 GNN 的介绍。虽然在本文讨论的定义域中集合的结构最少，但近年来 Transformer（Vaswani et al.，2017）和 Deep Sets（Zaheer et al.，2017）等广受欢迎的架构突出了集合的重要性。用第 4.1 节的语言说，假定给定节点特征矩阵 $\mathbf{X}$，但没有指定节点之间的邻接或顺序信息。具体架构由对节点之间相互作用建模到何种程度的选择产生。

空边集 无序集合没有提供任何额外结构或几何；因此可以认为，处理它们最自然的方式是完全独立地处理每个集合元素。这转化为作用于此类输入的置换等变函数，它已在第 4.1 节介绍过：对每个节点分别应用共享变换。采用描述 GNN（第 5.3 节）时的相同记号，这类模型可表示为

$$\mathbf{h}_u = \psi(\mathbf{x}_u),$$

其中 ψ 是可学习变换。可以看到，这是 $\mathcal{N}_u = \{u\}$ 或等价地 $A = I$ 时卷积型 GNN 的特例。这种架构通常称为 Deep Sets，以纪念 Zaheer et al.（2017）的工作，他们从理论上证明了此类架构的若干普适逼近性质。应注意，在处理点云的计算机视觉和图形学中经常需要处理无序集合；在那里，这类模型称为 PointNet（Qi et al.，2017）。

完全边集 虽然假定空边集是构造无序集合上函数的一种高效方式，我们往往预期集合元素之间存在某种关系结构，即节点之间存在潜在图。令 $A = I$ 会舍弃任何这类结构，可能使性能次优。反过来，也可以假定在没有其他先验知识时，不能预先排除节点之间的任何可能连接。此时假定完全图 $A = \mathbf{1}\mathbf{1}^\top$，等价地 $\mathcal{N}_u = \mathcal{V}$。由于我们假定无法获得任何相互作用系数，在这样的图上运行卷积型 GNN 相当于

$$\mathbf{h}_u = \phi\left(\mathbf{x}_u, \bigoplus_{v \in \mathcal{V}} \psi(\mathbf{x}_v)\right),$$

其中第二个输入 $\bigoplus_{v\in\mathcal{V}}\psi(\mathbf{x}_v)$ 对所有节点 u 相同，因此使模型的表达能力与完全忽略该输入等价，即与上述 $A=I$ 的情况等价。[12]

这促使我们使用表达能力更强的注意力型 GNN：

$$\mathbf{h}_u=\phi\left(\mathbf{x}_u,\bigoplus_{v\in\mathcal{V}}a(\mathbf{x}_u,\mathbf{x}_v)\psi(\mathbf{x}_v)\right), \tag{36}$$

它给出自注意力算子，即 Transformer 架构的核心（Vaswani et al., 2017）。假定对注意力系数进行某种归一化（例如 softmax），可以将所有标量 $a(\mathbf{x}_u,\mathbf{x}_v)$ 限制在 $[0,1]$ 内；因此，可以把自注意力看作针对某个下游任务进行基于梯度的优化时，作为副产品推断一个软邻接矩阵 $a_{uv}=a(\mathbf{x}_u,\mathbf{x}_v)$。

上述观点意味着，可以将 Transformer 精确地表述为完全图上的注意力 GNN（Joshi，2020）。[13]然而，这似乎与 Transformer 最初用于序列建模存在冲突：$\mathbf{h}_u$ 的表示应考虑节点 u 在序列中的位置，而完全图聚合会忽略这一点。Transformer 通过引入位置编码解决该问题：增强节点特征 $\mathbf{x}_u$ 以编码节点 u 在序列中的位置，通常取自频率依赖于 u 的正弦波样本。

在不存在自然节点顺序的图上，人们为这类位置编码提出了多种替代方案。虽然我们将留待以后讨论，但值得注意的一个有前景的方向是认识到：Transformer 使用的位置编码可以直接联系到离散傅里叶变换（DFT），因而与“环形网格”的图拉普拉斯特征向量相关。因此，Transformer 的位置编码隐式表示输入节点连成网格的假设。对更一般的图结构，可以直接使用（假定的）图的拉普拉斯特征向量；Dwivedi and Bresson（2020）在实证表现强大的 Graph Transformer 模型中利用了这一观察。

推断边集 最后，可以尝试学习潜在关系结构，得到既不是 I 也不是 $\mathbf{1}\mathbf{1}^\top$ 的一般 A。为 GNN 推断潜在邻接矩阵 A 的问题通常称为潜在图推断，是图表示学习中的重要问题。这是因为假定 $A=I$ 的表达能力可能不足，而 $A=\mathbf{1}\mathbf{1}^\top$ 可能由于内存需求和需要聚合的大邻域而难以实现。此外，它最接

[12]这是 $\bigoplus$ 的置换不变性的直接结果。

[13]也可以使用消息传递型。虽然它在物理模拟和关系推理中很流行（例如 Battaglia et al.（2016）、Santoro et al.（2017））但使用并不像 Transformer 那么广泛。这可能是由于在完全图上计算向量消息的内存问题，也可能是向量消息不像自注意力提供的“软邻接”那样容易解释。

近“真实”问题：推断邻接矩阵 A 意味着检测 $\mathbf{X}$ 各行之间的有用结构，而这可能有助于提出变量之间因果关系等假设。

遗憾的是，这种表述必然提高建模复杂度。具体地说，它需要在结构学习目标（该目标是离散的，因此对基于梯度的优化具有挑战性）与图所用于的下游任务之间适当平衡。这使得潜在图推断成为极具挑战且复杂的问题。

5.5 等变消息传递网络

在图神经网络的许多应用中，节点特征（或其中一部分）不只是任意向量，而是几何实体的坐标。例如在处理分子图时，代表原子的节点可能包含原子类型以及三维空间坐标。我们希望对后一部分特征的处理方式，使它与分子在空间中变换的方式相同；换言之，除了前面讨论的标准置换等变性，还应对刚体运动（旋转、平移和反射）的欧几里得群 $E(3)$ 等变。

为了开展稍作简化的分析，我们区分节点特征 $\mathbf{f}_u \in \mathbb{R}^d$ 和节点空间坐标 $\mathbf{x}_u \in \mathbb{R}^3$；后者赋有欧几里得对称结构。在这一设定下，等变层显式地分别变换这两个输入，得到修改后的节点特征 $\mathbf{f}'_u$ 和坐标 $\mathbf{x}'_u$。

现在可以按照几何深度学习蓝图说明所需的等变性质。如果输入的空间分量经 $\mathfrak{g} \in E(3)$ 变换，表示为 $\rho(\mathfrak{g})\mathbf{x} = R\mathbf{x} + \mathbf{b}$，其中 R 是对旋转与反射建模的正交矩阵，$\mathbf{b}$ 是平移向量，那么输出的空间分量以相同方式变换，即 $\mathbf{x}'_u \mapsto R\mathbf{x}'_u + \mathbf{b}$，而 $\mathbf{f}'_u$ 保持不变。

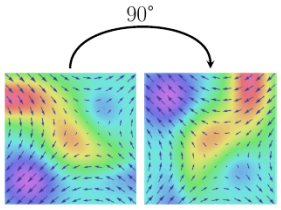
与前面一般图背景下讨论的置换等变函数空间类似，满足上述约束的 $E(3)$-等变层有很多，但并非所有这样的层都几何稳定或易于实现。事实上，实践中有用的等变层空间很可能可由简单分类描述，类似空间 GNN 层的“三种类型”。Satorras et al.（2021）以等变消息传递形式提出了一种优雅解法，其模型操作为

$$\mathbf{f}'_u = \phi\left(\mathbf{f}_u, \bigoplus_{v\in\mathcal{N}_u} \psi_f(\mathbf{f}_u, \mathbf{f}_v, \|\mathbf{x}_u - \mathbf{x}_v\|^2)\right),$$
$$\mathbf{x}'_u = \mathbf{x}_u + \sum_{v\neq u} (\mathbf{x}_u - \mathbf{x}_v)\psi_c(\mathbf{f}_u, \mathbf{f}_v, \|\mathbf{x}_u - \mathbf{x}_v\|^2),$$

其中 ψ_f 和 ψ_c 是两个不同的可学习函数。可以证明，这种聚合对空间坐标的欧几里得变换等变。这是因为 $\mathbf{f}'_u$ 对 $\mathbf{x}_u$ 的唯一依赖来自距离 $\|\mathbf{x}_u - \mathbf{x}_v\|^2$，

而 $E(3)$ 的作用必然保持节点间距离。此外，这样一层的计算可以视为“消息传递”型 GNN 的特例，因此易于高效实现。

总之，与普通 GNN 不同，Satorras et al.（2021）能够正确处理图中每个点的“坐标”。现在将它们视为 $E(3)$ 群的成员，这意味着在输入旋转、反射和平移下，网络输出会正确变化。然而，特征 $\mathbf{f}_u$ 仍按通道处理，被假定为在这些变换下不变的标量。这限制了该框架能够捕获的空间信息类型。例如，可能希望将某些特征编码为向量——如点的速度——它们应在变换下改变方向。Satorras et al.（2021）在其一种架构变体中引入速度概念，部分缓解了这一问题。速度是每个点的三维向量性质，会适当地旋转。然而，这只是在 $E(3)$ 等变网络中可以学习的一般表示的一个小子空间。一般地，节点特征可以编码任意维数的张量，仍按照 $E(3)$ 以良好定义的方式变换。



标量特征（热图）在旋转下不变，向量特征（箭头）则可能改变方向。前述简单 $E(3)$ 等变 GNN 没有考虑这一点。

因此，虽然上述架构已经为许多实际输入表示提供了优雅的等变解法，但在某些情形下，可能希望探索满足等变性质的更广泛函数集合。现有处理这类设定的方法可分为两类：不可约表示（前述层是其简化实例）和正则表示。下面简要综述，将详细讨论留待未来工作。

不可约表示 不可约表示建立在如下发现之上：旋转—平移群的所有元素都可以化为不可约形式，即由块对角矩阵旋转的向量。关键的是，每个块都是一个 Wigner D 矩阵（前述球面 CNN 的傅里叶基）。这一类方法使用等变核，从一组不可约表示映射到另一组。为找出全部等变映射，可以直接求解这些核上的等变性约束。其解构成等变基矩阵的线性组合，这些基矩阵由 Clebsch–Gordan 矩阵和球谐函数导出。

不可约表示方法的早期例子包括 Tensor Field Networks（Thomas et al.，2018）和 3D Steerable CNN（Weiler et al.，2018），它们都是作用于点云的卷积模型。Fuchs et al.（2020）的 SE(3)-Transformer 将该框架扩展到图定义域，使用注意力层而非卷积层。此外，虽然我们集中讨论 Satorras et al.（2021）的特例解，仍应指出，对图上旋转或平移等变预测的需求在历史上也曾在其他领域探索，包括用于点云的 Dynamic Graph CNN（Wang et al.，2019b），以及用于量子化学的高效消息传递模型 SchNet（Schütt et al.，2018）和 DimeNet（Klicpera et al.，2020）。

正则表示 虽然不可约表示方法很有吸引力，但它需要直接推理底层群表示，可能较为繁琐，而且仅适用于紧群。正则表示方法更一般，但带来额外计算负担：要实现严格等变性，就需要为所有群元素存储潜在特征嵌入的副本。[14]

这一领域中一种有前景的方法，旨在通过指数映射和对数映射的定义来满足对李群的等变性，并有望支持对各种对称群快速原型设计。虽然李群超出本节范围，我们请读者参阅这一方向近期两个成功例子：Finzi et al.（2020）的 LieConv 和 Hutchinson et al.（2020）的 LieTransformer。

本节介绍的方法是处理几何图数据、使其对底层几何显式等变的流行方式。如第 4.6 节所述，网格是几何图的特殊实例，可以理解为连续曲面的离散化。接下来将研究针对网格的等变神经网络。

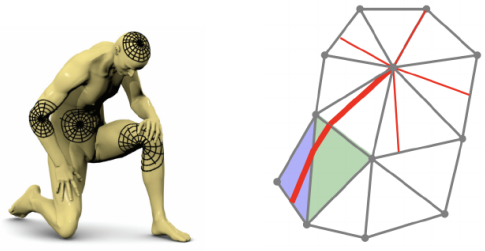
5.6 内禀网格 CNN

网格，特别是三角网格，是计算机图形学的基本工具，也许是对三维对象建模最常见的方法。深度学习总体上以及 CNN 在计算机视觉中的显著成功，使图形学和几何处理社区在 2010 年代中期对为网格数据构建类似架构产生浓厚兴趣。

测地局部块 大多数网格深度学习架构通过离散化或近似指数映射，并在切平面的坐标系中表达滤波器，来实现式 (21) 形式的卷积滤波器。从点

[14]事实上，这种方法最早由前面介绍的群卷积神经网络开创。

$u = \gamma(0)$ 向附近点 $v = \gamma(T)$ 发出测地线 $\gamma : [0, T] \to \Omega$，定义了局部测地极坐标系 $(r(u, v), \vartheta(u, v))$：其中 r 是 u, v 之间的测地距离（测地线 γ 的长度），ϑ 是 $\gamma'(0)$ 与某个局部参考方向之间的夹角。这允许定义测地局部块 $x(u, r, \vartheta) = x(\exp_u \widetilde{\omega}(r, \vartheta))$，其中 $\widetilde{\omega}_u : [0, R] \times [0, 2\pi) \to T_u\Omega$ 是局部极坐标标架。



左：测地局部块示例。为使所得局部块在拓扑上是圆盘，其半径 R 必须小于单射半径。右：网格上离散测地线的构造。

在离散为网格的曲面上，测地线是穿过三角形面的折线。传统上使用快速行进算法计算测地线（Kimmel and Sethian，1998）；该算法是对称为程函方程的非线性偏微分方程的高效数值近似，这类方程出现在介质中波传播的物理模型里。Kokkinos et al.（2012）将这一方案改用于计算局部测地块，后来 Masci et al.（2015）又用它构建 Geodesic CNN，即最早的网格内禀类 CNN 架构。

各向同性滤波器 重要的是，定义测地局部块时，参考方向和局部块定向的选择存在歧义。这恰好是规范选择的歧义；局部坐标系只确定到任意旋转（或角坐标平移 $x(u, r, \vartheta + \vartheta_0)$），而且每个节点的旋转都可能不同。最直接的解决方案或许是使用形式为 $\theta(r)$ 的各向同性滤波器，对邻居特征进行与方向无关的聚合：

$$(x \star \theta)(u) = \int_0^R \int_0^{2\pi} x(u, r, \vartheta)\theta(r)\, dr\, d\vartheta.$$

第 4.4–4.6 节讨论的谱滤波器属于这一类，因为它们基于各向同性的拉普拉斯算子。然而，这种方法舍弃了重要的方向信息，可能无法提取边缘状特征。

固定规范 另一种方法是固定某个规范，我们已在第 4.4 节提及。Monti et al.（2017）使用主曲率方向：虽然这一选择不是内禀的，并可能在平坦点（曲率消失处）或曲率均匀处（如理想球面）存在歧义，作者表明它适合处理近似分段刚性的可形变人体形状。后续工作，例如 Melzi et al.（2019），展示了在网格上可靠地内禀构造规范的方法：计算内禀函数的（内禀）梯度。虽然这类切向量场可能有奇点，即在某些点消失，但整体过程对噪声和重网格化非常鲁棒。

角向池化 Masci et al.（2015）使用了另一种称为角向最大池化的方法。此时滤波器 $\theta(r,\vartheta)$ 是各向异性的，但将它与函数在所有可能旋转下匹配，再聚合结果：

$$(x \star \theta)(u) = \max_{\vartheta_0 \in [0,2\pi)} \int_0^R \int_0^{2\pi} x(u,r,\vartheta)\theta(r,\vartheta+\vartheta_0)\, dr\, d\vartheta.$$

在概念上，可以将其想象为使测地局部块与旋转滤波器相关，并收集最强响应。

在网格上，可以用称为局部块算子的构造将连续积分离散化（Masci et al.，2015）。在节点 u 周围的测地局部块中，用局部极坐标 (r_{uv},ϑ_{uv}) 表示的邻居节点 $\mathcal{N}_u$，由一组权重函数 $w_1(r,\vartheta),\dots,w_K(r,\vartheta)$ 加权（见图 18，它们起“软像素”的作用）并聚合：[15]

$$(x \star \theta)_u = \frac{\sum_{k=1}^K w_k \sum_{v\in\mathcal{N}_u}(r_{uv},\vartheta_{uv})x_v\theta_k}{\sum_{k=1}^K w_k \sum_{v\in\mathcal{N}_u}(r_{uv},\vartheta_{uv})\theta_k},$$

其中 $\theta_1,\dots,\theta_K$ 是滤波器的可学习系数。多通道特征用一组适当滤波器逐通道处理。Masci et al.（2015）和 Boscaini et al.（2016a）使用预先定义的权重函数 w，而 Monti et al.（2017）进一步允许这些函数可学习。

规范等变滤波器 各向同性滤波器和角向最大池化都会产生对规范变换不变的特征，它们按平凡表示 $\rho(\mathfrak{g})=1$ 变换，其中 $\mathfrak{g}\in SO(2)$ 是局部坐标标架的旋转。这一观点暗示了另一种方法，由 Cohen et al.（2019）和 de Haan et al.（2020）提出并在第 4.5 节讨论：网络计算的特征与结构群 $\mathfrak{G}$ 的任意表

[15] 通常使用多跳邻居。

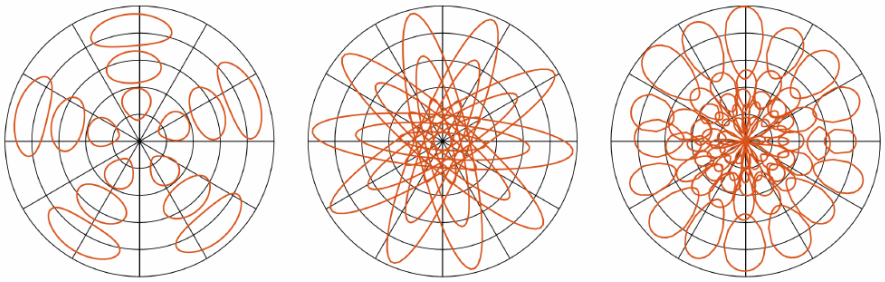


图 18: 从左到右：Geodesic CNN（Masci et al.，2015）、Anisotropic CNN（Boscaini et al.，2016b）和 MoNet（Monti et al.，2017）使用的局部块算子示例。权重函数 $w_k(r,\vartheta)$ 的等值集以红色显示。

示 ρ 相关联，例如分别对应坐标标架旋转或旋转加反射的 $SO(2)$ 或 $O(2)$。切向量按照标准表示 $\rho(\mathfrak{g})=\mathfrak{g}$ 变换。另一个例子是，将同一滤波器的 n 个旋转副本进行匹配所得到的特征向量，在规范旋转下按循环平移变换；这称为循环群 C_n 的正则表示。

如第 4.5 节所述，处理这类与非平凡表示相关联的几何特征时，必须先将它们平行移动到同一向量空间，再应用滤波器。在网格上，可以通过 de Haan et al.（2020）描述的下列消息传递机制实现。设 $\mathbf{x}_u\in\mathbb{R}^d$ 是网格节点 u 的 d 维输入特征。这个特征相对于 u 处某个任意选择的规范表示，并假定它在规范旋转下按 $\mathfrak{G}=SO(2)$ 的表示 ρ_{in} 变换。类似地，网格卷积的输出特征 $\mathbf{h}_u$ 是 d' 维的，应按 ρ_{out} 变换；后者可由网络设计者自由选择。

类比图神经网络，可以通过将 u 的邻居 $\mathcal{N}_u$（以及 u 本身）的消息发送给 u，在网格上实现规范等变卷积 (23)：

$$\mathbf{h}_u=\Theta_{\text{self}}\mathbf{x}_u+\sum_{v\in\mathcal{N}_u}\Theta_{\text{neigh}}(\vartheta_{uv})\rho(g_{v\to u})\mathbf{x}_v, \tag{37}$$

其中 $\Theta_{\text{self}},\Theta_{\text{neigh}}(\vartheta_{uv})\in\mathbb{R}^{d'\times d}$ 是学习得到的滤波器矩阵。结构群元素 $g_{v\to u}\in SO(2)$ 表示从 v 到 u 的平行移动效果，相对于 u,v 处的规范表达，可对每个网格预先计算。其作用由输运矩阵 $\rho(g_{v\to u})\in\mathbb{R}^{d\times d}$ 编码。矩阵 $\Theta_{\text{neigh}}(\vartheta_{uv})$ 依赖于邻居 v 相对于 u 处参考方向（例如标架第一轴）的角

度 ϑ_{uv}，因此这一核是各向异性的：不同邻居受到不同处理。[16]

如第 4.5 节所解释的，为使 $\mathbf{h}(u)$ 是良好定义的几何量，它在规范变换下应按 $\mathbf{h}(u) \mapsto \rho_{\text{out}}(\mathbf{g}^{-1}(u))\mathbf{h}(u)$ 变换。当对所有 $\vartheta \in SO(2)$ 满足 $\Theta_{\text{self}}\rho_{\text{in}}(\vartheta) = \rho_{\text{out}}(\vartheta)\Theta_{\text{self}}$，并且 $\Theta_{\text{neigh}}(\vartheta_{uv} - \vartheta)\rho_{\text{in}}(\vartheta) = \rho_{\text{out}}(\vartheta)\Theta_{\text{neigh}}(\vartheta_{uv})$ 时，确实如此。[17]由于这些约束是线性的，满足它们的矩阵 Θ_{self} 与矩阵值函数 Θ_{neigh} 的空间是线性子空间，因此可以将它们参数化为具有可学习系数的基核线性组合：$\Theta_{\text{self}} = \sum_i \alpha_i \Theta^i_{\text{self}}$、$\Theta_{\text{neigh}} = \sum_i \beta_i \Theta^i_{\text{neigh}}$。

5.7 循环神经网络

到目前为止，我们的讨论一直假定输入仅在给定定义域上具有空间结构。然而，在许多常见应用中，输入也可以被视为序列（例如视频、文本或语音）。此时假定输入由任意多个步骤构成，每一步 t 都提供一个输入信号，记为 $\mathbf{X}^{(t)} \in \mathcal{X}(\Omega^{(t)})$。

虽然一般而言定义域可以与其上的信号一起随时间演化，但通常假定对所有 t 定义域保持固定，即 $\Omega^{(t)} = \Omega$。这里我们仅关注这种情况，但也要指出例外很常见。[18]社交网络是常常需要考虑定义域随时间变化的例子，因为新连接会不断创建和删除。这种设定中的定义域通常称为动态图（Xu et al., 2020a；Rossi et al., 2020）。

各个 $\mathbf{X}^{(t)}$ 输入通常具有有用的对称性，因此可用先前讨论的任一种架构进行非平凡处理。常见例子包括：视频（Ω 是固定网格，信号是帧序列）；fMRI 扫描（Ω 是表示大脑皮层几何的固定网格，响应所呈现的刺激，不同区域在不同时间激活）；交通流网络（Ω 是表示道路网络的固定图，例如在各节点记录平均交通速度）。

假定编码器函数 $f(\mathbf{X}^{(t)})$ 提供适合问题粒度并尊重输入定义域对称性的潜在表示。以视频帧处理为例：每个时间步都给出一个表示为 $n \times d$ 矩阵

[16]注意 d 是特征维数，不一定等于网格维数 2。

[17]这里滥用记号，将二维旋转与角度 ϑ 等同。

[18]将定义域视为静态还是动态取决于时间尺度。例如，道路网络确实随时间改变（新道路建成，旧道路拆除），但明显慢于交通流变化。同样，在社交网络中，互动变化（例如 Twitter 用户转发推文）的频率远高于关注关系图的变化。

$\mathbf{X}^{(t)}$ 的网格结构输入，其中 n 是像素数（时间上固定），d 是输入通道数（RGB 帧为 $d=3$）。此外，我们关心整个帧层面的分析，此时适宜将 f 实现为平移不变 CNN，输出时间步 t 的帧的 k 维表示 $\mathbf{z}^{(t)}=f(\mathbf{X}^{(t)})$。[19]

剩下的任务是适当地概括跨所有时间步的向量序列 $\mathbf{z}^{(t)}$。动态聚合这些信息的一种典型方式是使用循环神经网络（RNN）：它尊重输入的时间推进，也容易允许新数据点在线到达。我们将展示，RNN 本身是一种有趣的几何架构，因为它对输入 $\mathbf{z}^{(t)}$ 实现了一种颇为特殊的对称性。[20]

SimpleRNN 在每一步，循环神经网络计算一个 m 维概括向量 $\mathbf{h}^{(t)}$，概括截至并包含 t 的所有输入步骤。这个（部分）概括依赖当前步骤特征和前一步的概括，通过共享更新函数 $R:\mathbb{R}^k\times\mathbb{R}^m\to\mathbb{R}^m$ 计算（概览见图 19）：

$$\mathbf{h}^{(t)}=R(\mathbf{z}^{(t)},\mathbf{h}^{(t-1)}). \tag{38}$$

由于 $\mathbf{z}^{(t)}$ 和 $\mathbf{h}^{(t-1)}$ 都是展平后的向量表示，最容易将 R 表示为单个全连接神经网络层，通常称为 SimpleRNN（见 Elman（1990）、Jordan（1997））：

$$\mathbf{h}^{(t)}=\sigma(W\mathbf{z}^{(t)}+U\mathbf{h}^{(t-1)}+\mathbf{b}), \tag{39}$$

其中 $W\in\mathbb{R}^{k\times m}$、$U\in\mathbb{R}^{m\times m}$ 和 $\mathbf{b}\in\mathbb{R}^m$ 是可学习参数，σ 是激活函数。[21]虽然这会在网络计算图中引入环，实践中会将网络展开适当的步数，以便应用时间反向传播（Robinson and Fallside，1987；Werbos，1988；Mozer，1989）。

概括向量随后可以适当地用于下游任务：若序列每一步都需要预测，就可以对每个 $\mathbf{h}^{(t)}$ 分别应用共享预测器；若要分类整个序列，通常将最终概括 $\mathbf{h}^{(T)}$ 送入分类器，其中 T 是序列长度。初始概括向量通常设为零向量

[19]这一例子没有损失一般性；例如可对时空图上的节点级输出进行等价分析，唯一区别是编码器 f 的选择（届时它将是置换等变 GNN）。

[20]向量 $\mathbf{z}^{(t)}$ 可以看作时间网格上的点，因此在某些情况下也可以用 CNN 处理。Transformer 也越来越常用于处理一般序列输入。

[21]尽管名字简单，SimpleRNN 的表达能力却很强。例如，Siegelmann and Sontag（1995）表明，这类模型是图灵完备的，意味着它们可能表示我们能够在计算机上执行的任何计算。

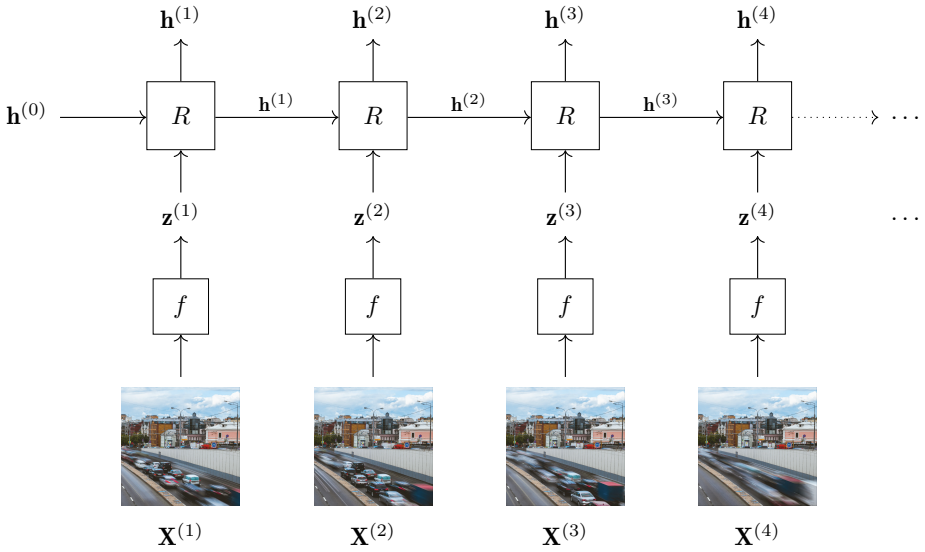


图 19: 用 RNN 处理视频输入的示意。每个输入视频帧 $\mathbf{X}^{(t)}$ 经共享函数 f（例如平移不变 CNN）处理为展平后的表示 $\mathbf{z}^{(t)}$。随后 RNN 更新函数 R 在这些向量上迭代，更新概括向量 $\mathbf{h}^{(t)}$，概括截至并包含 $\mathbf{z}^{(t)}$ 的所有输入。计算由初始概括向量 $\mathbf{h}^{(0)}$ 启动，该向量可以预先指定或学习得到。

$\mathbf{h}^{(0)} = 0$，或设为可学习。分析初始概括向量的设置方式，也使我们能够推导出 RNN 呈现的一种有趣的平移等变性。

RNN 中的平移等变性 由于将各步 t 解释为离散时间步，输入向量 $\mathbf{z}^{(t)}$ 可以视为位于一维时间网格上。虽然直接将 CNN 的平移等变分析推广到这里很有吸引力，但这并不简单。[22]

为说明原因，假设将序列左移一步得到新序列 $\mathbf{z}'^{(t)} = \mathbf{z}^{(t+1)}$。人们可能想证明平移等变性所预期的 $\mathbf{h}'^{(t)} = \mathbf{h}^{(t+1)}$，但一般并不成立。考虑 $t = 1$，直接应用并展开更新函数得到

$$\mathbf{h}'^{(1)} = R(\mathbf{z}'^{(1)}, \mathbf{h}^{(0)}) = R(\mathbf{z}^{(2)}, \mathbf{h}^{(0)}), \tag{40}$$

$$\mathbf{h}^{(2)} = R(\mathbf{z}^{(2)}, \mathbf{h}^{(1)}) = R(\mathbf{z}^{(2)}, R(\mathbf{z}^{(1)}, \mathbf{h}^{(0)})). \tag{41}$$

因此，除非能保证 $\mathbf{h}^{(0)} = R(\mathbf{z}^{(1)}, \mathbf{h}^{(0)})$，否则不会得到平移等变性。对于 $t > 1$ 的步骤可以作类似分析。

幸运的是，只需稍微调整 $\mathbf{z}$ 的表示，并适当选择 R，就可以满足上式，从而展示 RNN 对平移等变的一种设定。问题主要是边界条件：上式含有被左移操作消去的 $\mathbf{z}^{(1)}$。为抽象掉这一问题，我们考察 RNN 对适当左填充序列 $\bar{\mathbf{z}}^{(t)}$ 的处理，其定义为

$$\bar{\mathbf{z}}^{(t)} = \begin{cases} 0, & t \le t_0, \\ \mathbf{z}^{(t-t_0)}, & t > t_0. \end{cases}$$

这样的序列允许最多左移 t_0 步而不丢失任何原始输入元素。[23]此外，无需单独处理右移；实际上右移等变性自然来自 RNN 方程。

现在可以像式 (40)–(41) 那样，再次分析 RNN 对左移序列 $\bar{\mathbf{z}}'^{(t)} = \bar{\mathbf{z}}^{(t+1)}$ 的操作：

$$\mathbf{h}'^{(1)} = R(\bar{\mathbf{z}}'^{(1)}, \mathbf{h}^{(0)}) = R(\bar{\mathbf{z}}^{(2)}, \mathbf{h}^{(0)}),$$
$$\mathbf{h}^{(2)} = R(\bar{\mathbf{z}}^{(2)}, \mathbf{h}^{(1)}) = R(\bar{\mathbf{z}}^{(2)}, R(\bar{\mathbf{z}}^{(1)}, \mathbf{h}^{(0)})) = R(\bar{\mathbf{z}}^{(2)}, R(0, \mathbf{h}^{(0)})),$$

[22]这种构造可推广到更高维网格，例如以扫描线方式处理图像。此类构造支持了一系列流行模型，例如 van den Oord et al.（2016b）的 PixelRNN。

[23]如果使用不同于零的填充向量，也可以进行等价分析。

只要 $t_0 \geq 1$，即应用了任意填充，代换 $\bar{\mathbf{z}}^{(1)} = 0$ 就成立。现在只需 $\mathbf{h}^{(0)} = R(0, \mathbf{h}^{(0)})$，就能保证左移一步等变，即 $\mathbf{h}'^{(t)} = \mathbf{h}^{(t+1)}$。[24]

换言之，$\mathbf{h}^{(0)}$ 必须选为函数 $\gamma(\mathbf{h}) = R(0, \mathbf{h})$ 的不动点。若适当选择更新函数 R，不仅可以保证这样的不动点存在，甚至可以直接迭代应用 R 至收敛而得到它，例如：

$$\mathbf{h}_0 = 0, \qquad \mathbf{h}_{k+1} = \gamma(\mathbf{h}_k), \tag{42}$$

其中指标 k 表示计算中对 R 的迭代，而上标 (t) 表示 RNN 的时间步。如果选择 R 使 γ 是压缩映射，这种迭代确实会收敛到唯一不动点。[25]因此可以迭代式 (42) 直到 $\mathbf{h}_{k+1} = \mathbf{h}_k$，并令 $\mathbf{h}^{(0)} = \mathbf{h}_k$。注意，这一计算等价于在序列左侧填充“足够多”的零向量。

RNN 的深度 也很容易堆叠多个 RNN：只需将 $\mathbf{h}^{(t)}$ 向量作为第二个 RNN 的输入序列。这种构造有时称为“深层 RNN”，但这种说法可能具有误导性。实际上，由于反复应用循环操作，即使单个 RNN“层”的深度也等于输入步数。

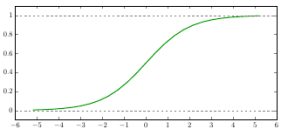
优化 RNN 时，这往往带来特殊困难的学习动力学，因为每个训练样本都会对更新网络的共享参数产生多次梯度更新。这里我们关注其中最突出的问题之一——梯度消失和梯度爆炸（Bengio et al.，1994）。鉴于 RNN 的深度和参数共享，这一问题尤其严重，也独自推动了若干最有影响力的 RNN 研究。更详细的综述可参见 Pascanu et al.（2013）；他们深入研究了 RNN 的训练动力学，并从解析、几何和动力系统等多种角度揭示这些挑战。

为说明梯度消失，考虑带 sigmoid 型激活函数 σ 的 SimpleRNN，其导数绝对值 $|\sigma'|$ 始终介于 0 和 1 之间。许多这样的值相乘会使梯度迅速趋于零，意味着输入序列的早期步骤可能完全无法影响网络参数更新。

例如，考虑下一个词预测任务（常见于预测键盘等），输入文本为“Petar 是塞尔维亚人。他出生于…… [长段文字] ……Petar 目前居住在____”。这

[24]以非常类似的方式，只要 $t_0 \geq s$，就能推导左移 s 步的等变性。

[25]压缩映射 $\gamma : \mathcal{X} \to \mathcal{X}$ 指在某个范数 $\|\cdot\|$ 下，它缩短点之间的距离：对所有 $x, y \in \mathcal{X}$ 和某个 $q \in [0, 1)$，有 $\|\gamma(x) - \gamma(y)\| \leq q\|x - y\|$。作为 Banach 不动点定理（Banach，1922）的直接推论，反复迭代该函数必然收敛到唯一不动点。



此类激活函数的例子包括 logistic 函数 $\sigma(x) = 1/(1 + \exp(-x))$ 和双曲正切 $\sigma(x) = \tanh x$。由于图像具有明显的 S 形，它们称为 sigmoid 型函数。

里要合理预测下一个词为“塞尔维亚”，可能只能依靠段落最开头的信息；但梯度到达这一步输入时很可能已经消失，使得从这类例子中学习非常困难。

深层前馈神经网络也曾受到梯度消失问题困扰，直到 ReLU 激活的发明（其梯度恰好等于零或一，从而解决了梯度消失问题）。然而，在 RNN 中使用 ReLU 容易导致梯度爆炸，因为此时更新函数的输出空间无界，且梯度下降会对每个输入步骤更新一次单元，迅速增大更新的尺度。历史上，梯度消失现象很早就被认识为使用循环网络的重大障碍。应对这一问题推动了更复杂 RNN 层的发展，下一节将介绍它们。

5.8 长短期记忆网络

显著减轻 RNN 梯度消失影响的一项关键发明是门控机制，它允许网络以数据驱动方式选择性地覆写信息。这类门控 RNN 的著名例子包括长短期记忆网络（LSTM；Hochreiter and Schmidhuber（1997））和门控循环单元（GRU；Cho et al.（2014））。这里主要讨论 LSTM，具体采用 Graves（2013）提出的变体，以说明这类模型的操作。LSTM 的概念很容易推广到其他门控 RNN。

在本节中，参照图 20 可能会很有帮助；它展示了正文将讨论的所有 LSTM 操作。

LSTM 通过引入记忆单元扩展循环计算，该单元存储在计算步骤之间保留的单元状态向量 $\mathbf{c}^{(t)} \in \mathbb{R}^m$。LSTM 直接根据 $\mathbf{c}^{(t)}$ 计算概括向量 $\mathbf{h}^{(t)}$，而 $\mathbf{c}^{(t)}$ 又使用 $\mathbf{z}^{(t)}$、$\mathbf{h}^{(t-1)}$ 和 $\mathbf{c}^{(t-1)}$ 计算。关键的是，单元不会仅依据 $\mathbf{z}^{(t)}$ 和 $\mathbf{h}^{(t-1)}$ 完全覆写，否则网络会遇到与 SimpleRNN 相同的问题。相反，先前单元状态的一部分可以保留，保留的比例由数据显式学习。

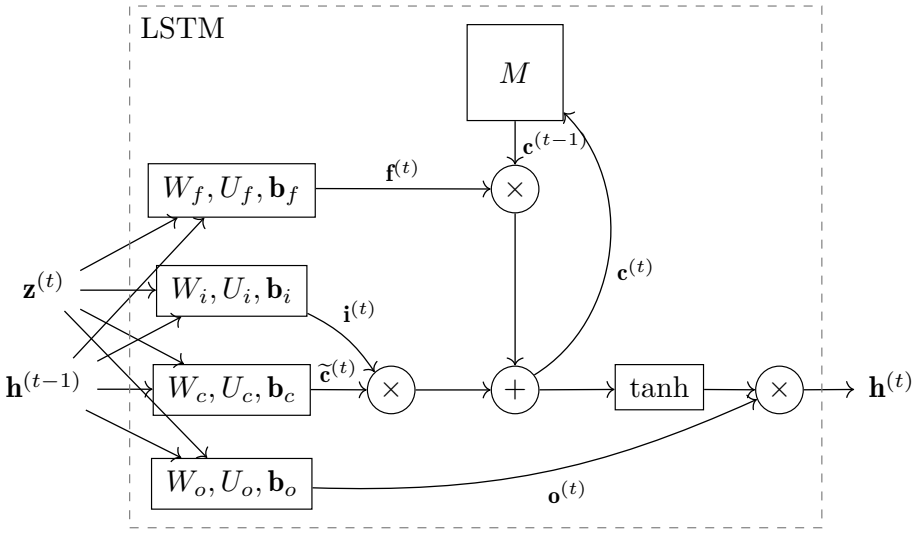


图 20: 长短期记忆网络（LSTM）的数据流，清楚标出了其组件与记忆单元 M。根据当前输入 $\mathbf{z}^{(t)}$、先前概括 $\mathbf{h}^{(t-1)}$ 和先前单元状态 $\mathbf{c}^{(t-1)}$，LSTM 预测更新后的单元状态 $\mathbf{c}^{(t)}$ 和概括 $\mathbf{h}^{(t)}$。

与 SimpleRNN 一样，我们对当前输入步和前一概括应用单层全连接神经网络来计算特征：[26]

$$\widetilde{\mathbf{c}}^{(t)} = \tanh(W_c\mathbf{z}^{(t)} + U_c\mathbf{h}^{(t-1)} + \mathbf{b}_c). \tag{43}$$

但如前所述，我们不允许整个向量进入单元，因此称其为候选特征向量并记为 $\widetilde{\mathbf{c}}^{(t)}$。LSTM 转而直接学习门控向量：它们是 $[0,1]$ 范围内的实值向量，决定允许多少信号进入、离开及覆写记忆单元。

计算三个这样的门，均基于 $\mathbf{z}^{(t)}$ 和 $\mathbf{h}^{(t-1)}$：输入门 $\mathbf{i}^{(t)}$ 计算允许进入单元的候选向量比例；遗忘门 $\mathbf{f}^{(t)}$ 计算要保留的先前单元状态比例；输出门 $\mathbf{o}^{(t)}$ 计算用于最终概括向量的新单元状态比例。通常也用单层全连接网络生成这些门，但采用 logistic sigmoid 激活 $\text{logistic}(x) = 1/(1+\exp(-x))$，以

[26]注意这里将激活函数设为 tanh；由于 LSTM 旨在缓解梯度消失问题，此时适合使用 sigmoid 型激活。

保证输出在 $[0,1]$ 范围内：[27]

$$\mathbf{i}^{(t)} = \text{logistic}(W_i\mathbf{z}^{(t)} + U_i\mathbf{h}^{(t-1)} + \mathbf{b}_i), \tag{44}$$

$$\mathbf{f}^{(t)} = \text{logistic}(W_f\mathbf{z}^{(t)} + U_f\mathbf{h}^{(t-1)} + \mathbf{b}_f), \tag{45}$$

$$\mathbf{o}^{(t)} = \text{logistic}(W_o\mathbf{z}^{(t)} + U_o\mathbf{h}^{(t-1)} + \mathbf{b}_o). \tag{46}$$

最后，适当地应用这些门解码新单元状态 $\mathbf{c}^{(t)}$，再由输出门调制，得到概括向量 $\mathbf{h}^{(t)}$：

$$\mathbf{c}^{(t)} = \mathbf{i}^{(t)} \odot \tilde{\mathbf{c}}^{(t)} + \mathbf{f}^{(t)} \odot \mathbf{c}^{(t-1)}, \tag{47}$$

$$\mathbf{h}^{(t)} = \mathbf{o}^{(t)} \odot \tanh(\mathbf{c}^{(t)}), \tag{48}$$

其中 $\odot$ 表示向量逐元素相乘。式 (43)–(48) 联合起来完整指定 LSTM 的更新规则；它现在也考虑单元向量 $\mathbf{c}^{(t)}$：[28]

$$(\mathbf{h}^{(t)}, \mathbf{c}^{(t)}) = R(\mathbf{z}^{(t)}, (\mathbf{h}^{(t-1)}, \mathbf{c}^{(t-1)})).$$

注意，由于 $\mathbf{f}^{(t)}$ 的值由 $\mathbf{z}^{(t)}$ 和 $\mathbf{h}^{(t-1)}$ 得到，因而可以直接从数据学习，LSTM 实际上学会了如何适当遗忘过去经验。事实上，$\mathbf{f}^{(t)}$ 的值直接出现在所有 LSTM 参数 $(W_*, U_*, \mathbf{b}_*)$ 的反向传播更新中，使网络能够以数据驱动方式显式控制跨时间步梯度消失的程度。

除了正面处理梯度消失问题，门控 RNN 还提供了一种对时间规整变换非常有用的不变性，而 SimpleRNN 无法达到这一点。

门控 RNN 的时间规整不变性 我们先在连续时间设定下说明时间规整的含义，以及循环模型需要满足什么条件才能对这类变换不变。[29]叙述主要遵循最初描述这一现象的 Tallec and Ollivier（2018）；他们也是最早从不变性视角研究 RNN 的研究者之一。

[27]三个门本身都是向量，即 $\mathbf{i}^{(t)}, \mathbf{f}^{(t)}, \mathbf{o}^{(t)} \in [0,1]^m$，因此它们可以控制每个维度中有多少信息通过门。

[28]这仍与式 (38) 的 RNN 更新蓝图相容：只需将概括向量视为 $\mathbf{h}^{(t)}$ 与 $\mathbf{c}^{(t)}$ 的拼接，有时记为 $\mathbf{h}^{(t)} \| \mathbf{c}^{(t)}$。

[29]我们关注连续设定，因为在那里更容易推理对时间的操作。

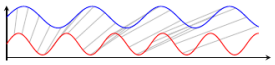
假定一个连续时间信号 $z(t)$，我们希望对它应用 RNN。为了将 RNN 对概括向量 $\mathbf{h}^{(t)}$ 的离散时间计算与连续域中的类似物 $h(t)$ 对齐，考察其线性 Taylor 展开：[30]

$$h(t+\delta) \approx h(t) + \delta \frac{dh(t)}{dt}. \tag{49}$$

令 $\delta = 1$，得到 $h(t)$ 与 $h(t+1)$ 的关系，这恰是 RNN 更新函数 R（式 (38)）所计算的关系。也就是说，RNN 更新函数满足下列微分方程：

$$\frac{dh(t)}{dt} = h(t+1) - h(t) = R(z(t+1), h(t)) - h(t). \tag{50}$$

我们希望 RNN 对信号采样方式（例如改变时间的计量单位）具有鲁棒性，以处理其中的不完善或不规则之处。形式上，将时间规整操作 $\tau : \mathbb{R}_+ \to \mathbb{R}_+$ 记为任意单调递增的时间间可微映射。选择记号 τ 是因为时间规整代表时间的自同构。[31]



时间重标度示意。

进一步地，如果对某类模型中的任意模型及任意这样的 τ，都存在同一类中的另一个模型（可能相同），使其处理规整数据的方式与原模型处理未规整数据的方式相同，就称这一模型类对时间规整不变。这可能非常有用：若一个 RNN 类能够很好地对短期依赖建模，又可证明该类对时间规整不变，那么就知道可以训练这种模型，使其也能有效捕获长期依赖，因为后者对应对具有短期依赖的信号进行时间膨胀。如将要看到的，LSTM 等门控 RNN 被提出用于长程依赖建模并非偶然。实现时间规整不变性与 LSTM 的输入门、遗忘门和输出门等门控机制的存在紧密相关。

当时间经 τ 规整时，RNN 在时间 t 观察到的信号是 $z(\tau(t))$；为了对这种规整保持不变，它应预测等价规整的概括函数 $h(\tau(t))$。再次使用 Taylor

[30] 我们用 $h(t)$ 表示时间 t 的连续信号，用 $\mathbf{h}^{(t)}$ 表示时间步 t 的离散信号。

[31] 这种规整操作可以很简单，例如时间重标度 $\tau(t) = 0.7t$；在离散设定中，这相当于大约每 1.43 步接收一次新输入。它也允许变化多样的采样速率，例如在整个时间域中自由加速或减速采样。

展开的论证，可以推导出 RNN 更新 R 应满足的、针对规整时间的式 (50) 形式：

$$\frac{dh(\tau(t))}{d\tau(t)} = R(z(\tau(t+1)), h(\tau(t))) - h(\tau(t)). \tag{51}$$

然而，上述导数相对于规整时间 $\tau(t)$ 计算，因而没有考虑原始信号。为使模型显式考虑规整变换，需要相对于 t 对规整后的概括函数求导。应用链式法则，得到微分方程：

$$\begin{aligned}\frac{dh(\tau(t))}{dt} &= \frac{dh(\tau(t))}{d\tau(t)}\frac{d\tau(t)}{dt} \\ &= \frac{d\tau(t)}{dt}R(z(\tau(t+1)), h(\tau(t))) - \frac{d\tau(t)}{dt}h(\tau(t)).\end{aligned} \tag{52}$$

而且，为使连续时间 RNN 对任意时间规整 $\tau(t)$ 保持不变，它需要能显式表示导数 $d\tau(t)/dt$；这一导数并不假定预先已知！因此需要引入可学习函数 Γ 近似该导数。例如，Γ 可以是考虑 $z(t+1)$ 和 $h(t)$ 并预测标量输出的神经网络。

现在注意，从时间规整下的离散 RNN 模型角度看，其输入 $\mathbf{z}^{(t)}$ 对应于 $z(\tau(t))$，概括 $\mathbf{h}^{(t)}$ 对应于 $h(\tau(t))$。为了获得保持时间规整不变所需的 $\mathbf{h}^{(t)}$ 与 $\mathbf{h}^{(t+1)}$ 之间的关系，我们对 $h(\tau(t))$ 作一步 Taylor 展开：

$$h(\tau(t+\delta)) \approx h(\tau(t)) + \delta\frac{dh(\tau(t))}{dt},$$

再次令 $\delta = 1$，代入式 (52)，然后离散化：

$$\begin{aligned}\mathbf{h}^{(t+1)} &= \mathbf{h}^{(t)} + \frac{d\tau(t)}{dt}R(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) - \frac{d\tau(t)}{dt}\mathbf{h}^{(t)} \\ &= \frac{d\tau(t)}{dt}R(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) + \left(1 - \frac{d\tau(t)}{dt}\right)\mathbf{h}^{(t)}.\end{aligned}$$

最后，用上述可学习函数 Γ 替换 $d\tau(t)/dt$，得到所需的时间规整不变 RNN 形式：

$$\begin{aligned}\mathbf{h}^{(t+1)} = \Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})R(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) \\ + \big(1 - \Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})\big)\mathbf{h}^{(t)}.\end{aligned} \tag{53}$$

很容易推知 SimpleRNN（式 (39)）不是时间规整不变的，因为它没有式 (53) 中的第二项。它完全用 $R(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})$ 覆写 $\mathbf{h}^{(t)}$，相当于假定完全没有时间规整：$d\tau(t)/dt = 1$，即 $\tau(t) = t$。

此外，基于 R 将连续时间 RNN 与离散 RNN 联系起来，依赖 Taylor 近似的精确程度；该近似只有在时间规整导数不太大，即 $d\tau(t)/dt \lesssim 1$ 时才成立。直观解释是：如果时间规整在某处压缩时间，使时间增量 $t \to t+1$ 大到中间数据变化未被采样，模型就无法期望以与原输入相同的方式处理时间规整后的输入，因为它无法获得相同信息。反过来，任意形式的时间膨胀（在离散情形对应于在输入时间序列中插入零）在我们的框架中都是完全允许的。

结合 τ 单调递增的要求 $d\tau(t)/dt > 0$，可以将 Γ 的输出空间限定为 $0 < \Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) < 1$，从而引出对 Γ 使用 logistic sigmoid 激活，例如

$$\Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) = \text{logistic}(W_\Gamma \mathbf{z}^{(t+1)} + U_\Gamma \mathbf{h}^{(t)} + \mathbf{b}_\Gamma),$$

这与 LSTM 门控方程（例如式 (44)）完全对应。主要区别是 LSTM 计算门控向量，而式 (53) 意味着 Γ 应输出标量。向量化的门（Hochreiter，1991）允许在 $\mathbf{h}^{(t)}$ 的每个维度拟合不同的规整导数，从而同时处理多个时间范围。

有必要停下来总结一下：通过要求 RNN 类对非破坏性时间规整不变，我们推导出它必须具有的形式（式 (53)），并表明它恰好对应于门控 RNN 类。从这一观点看，门的主要作用是准确拟合规整变换的导数 $d\tau(t)/dt$。

类不变性的概念与我们之前研究的不变性有所不同。具体地说，一旦在经 $\tau_1(t)$ 时间规整的输入上训练了一个门控 RNN，通常不能将它零样本迁移到经另一 $\tau_2(t)$ 规整的信号。类不变性只保证门控 RNN 足够强大，能以相同方式拟合这两个信号，但模型参数可能截然不同。[32]尽管如此，认识到有效门控机制与拟合规整导数密切相关，可以为门控 RNN 的优化提供有用建议，下面简要展示。

例如，我们通常可以假定信号中希望追踪的依赖范围为 $[T_l, T_h]$ 时间步。通过分析式 (52) 的解析解，可以表明门控 RNN 遗忘 $\mathbf{h}^{(t)}$ 的特征时间与

[32]一种可以零样本迁移的情形是假定第二次时间规整是第一次的时间重标度：$\tau_2(t) = \alpha\tau_1(t)$。将经 τ_1 预训练的门控 RNN 迁移到经 τ_2 规整的信号，只需重标度门：$\Gamma_2(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)}) = \alpha\Gamma_1(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})$；$R$ 可保持其参数不变（$R_1 = R_2$）。

$1/\Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})$ 成正比。因此，为有效记住假定范围内的信息，希望门值位于 $[1/T_h, 1/T_m]$ 之间。

进一步假设 $\mathbf{z}^{(t)}$ 和 $\mathbf{h}^{(t)}$ 大致以零为中心——这通常是使用层归一化等变换（Ba et al., 2016）的副产品——便可假定 $\mathbb{E}[\Gamma(\mathbf{z}^{(t+1)}, \mathbf{h}^{(t)})] \approx \text{logistic}(\mathbf{b}_\Gamma)$。因此控制门控机制的偏置向量是控制有效门值的有力方法。

结合这两点，我们得出结论：通过初始化 $\mathbf{b}_\Gamma \sim -\log(\mathcal{U}(T_l, T_h) - 1)$ 可以得到适当范围的门值，其中 $\mathcal{U}$ 是均匀实数分布。[33]Tallec and Ollivier（2018）将这一建议称为 chrono 初始化，并在经验上表明它改善门控 RNN 的长程依赖建模。

使用 RNN 的序列到序列学习 使用 RNN 支持的计算，一个著名的历史例子是序列到序列翻译任务，例如自然语言机器翻译。Sutskever et al.（2014）开创性的 seq2seq 工作，通过将概括向量 $\mathbf{h}^{(T)}$ 作为解码器 RNN 的初始输入，并将 RNN 模块的输出作为下一步输入，实现了这一目标。

这给概括向量 $\mathbf{h}^{(T)}$ 带来很大表示压力。在深度学习中，$\mathbf{h}^{(T)}$ 有时称为瓶颈。它的固定容量必须足以用有利于生成相应序列的方式表示整个输入序列的内容，同时还要支持长度差别很大的输入序列（图 21）。[34]

实际上，输出的不同步骤可能希望关注输入的不同部分，而所有这些选择都难以由瓶颈向量表示。基于这一观察，Bahdanau et al.（2014）提出了流行的循环注意力模型。在处理的每一步，RNN 生成一个查询向量；该查询向量再与每个时间步的表示 $\mathbf{h}^{(t)}$ 交互，主要通过计算它们的加权和来实现。该模型开创了基于神经内容的注意力，早于 Transformer 模型的成功。

最后，虽然注意力为动态关注输入内容的一部分提供了柔性方式，大量工作也学习了更显式地引导注意力到输入的方法。一种具有强大算法基础的方法是 Vinyals et al.（2015）的指针网络，它提出对循环注意力作简单修改，以便能够指向不同长度输入的元素。这些发现随后被推广为 set2set 架构（Vinyals et al., 2016）：该架构以指针网络支持的 LSTM 将 seq2seq 模型推广到无序集合。

---

[33]Gers and Schmidhuber（2000）及 Jozefowicz et al.（2015）已发现这一见解；他们根据经验建议将 LSTM 遗忘门偏置初始化为常数正向量，例如 1。

[34]瓶颈效应近来也受到图表示学习（Alon and Yahav, 2020）以及神经算法推理（Cappart et al., 2021）社区的广泛关注。

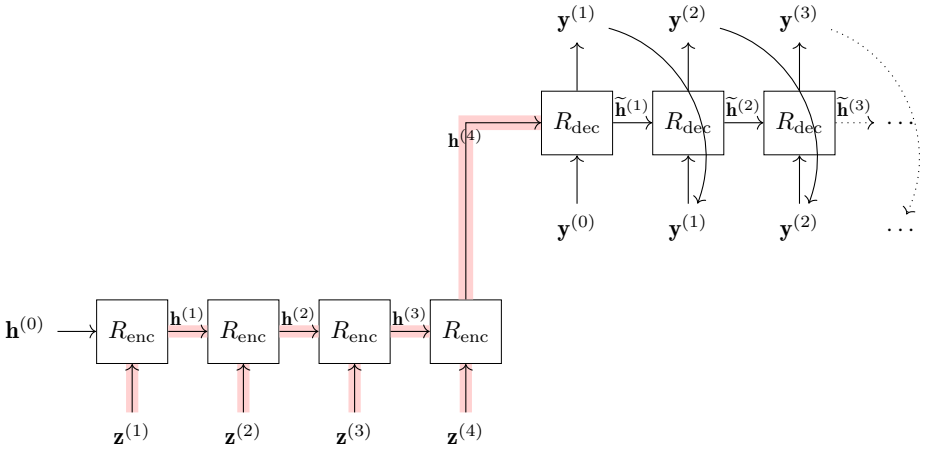
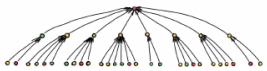


图 21: 带 RNN 编码器 R_{enc} 和 RNN 解码器 R_{dec} 的典型 seq2seq 架构。解码器以编码器输出的最终概括向量 $\mathbf{h}^{(T)}$ 初始化，随后以自回归方式运行：每一步都将前一步的预测输出反馈为 R_{dec} 的输入。红线也展示了瓶颈问题：概括向量 $\mathbf{h}^{(T)}$ 必须存储翻译输入序列所需的全部相关信息，随着输入长度增长，这越来越困难。



图表示学习中的瓶颈效应示意。

第六章　问题与应用

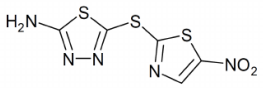
现实世界产生的数据中，不变性与对称性极为常见。因此，21 世纪机器学习的一些最流行应用直接产生于几何深度学习，也许有时人们并未充分意识到这一点，这并不令人意外。我们希望为读者概述几何深度学习中有影响的工作以及令人振奋、富有前景的新应用；这一概述绝不全面。我们的动机有二：展示五类几何定义域常见于哪些科学和工业问题的具体实例，并为进一步研究几何深度学习原理和架构提供更多动力。

化学与药物设计　图表示学习最有前景的应用之一是计算化学和药物开发。传统药物是小分子，设计目的是在化学上与某个靶分子（通常是蛋白质）结合，从而激活或干扰某种与疾病相关的化学过程。[1]不幸的是，药物开发是极其漫长和昂贵的过程：在写作时，将一种新药推向市场通常需要十年以上，花费超过十亿美元。原因之一是测试成本，许多药物在不同阶段失败，能够进入最后阶段的候选药物不足 5%（例如 Gaudelet et al.（2020））。

由于可通过化学方法合成的分子空间非常大（估计约为 10^{60}），无法通过实验寻找同时具备靶标结合亲和力、低毒性、溶解性等合适性质的候选分子，因此需要虚拟或计算机模拟筛选，即使用计算技术识别有前景的分子。机器学习技术在这一任务中发挥着越来越重要的作用。Stokes et al.（2020）近期展示了几何深度学习用于虚拟药物筛选的一个著名例子：他们训练图神经网络，预测候选分子是否抑制模式细菌大肠杆菌的生长，由此有效发现原本用于治疗糖尿病的分子 Halicin 是一种效力很强的抗生素，甚至对已知具

[1]许多药物并非被设计出来，而是往往通过偶然机会被发现。一些药物历史上来自植物界，这一点反映在它们的名称中：例如，乙酰水杨酸（俗称阿司匹林）存在于柳树（*Salix alba*）树皮中，而柳树的药用性质自古为人所知。

有抗药性的菌株也有效。这一发现受到科学界和大众媒体广泛报道。



Halicin 的分子图。

更广泛地说，将图神经网络应用于建模为图的分子一直是非常活跃的领域；近期提出了多种受物理启发的专门架构，例如纳入对旋转和平移的等变性（见 Thomas et al.（2018）、Anderson et al.（2019）、Fuchs et al.（2020）、Satorras et al.（2021））。此外，Bapst et al.（2020）成功展示了 GNN 在预测建模玻璃动力学方面的效用，其表现优于先前可用的基于物理的模型。从历史上看，计算化学中的许多工作是现代图神经网络架构的先驱，与后者具有许多共同特征。

药物再定位 虽然生成全新候选药物是一种可能可行的方法，开发新疗法还有一条更快、更便宜的途径：药物再定位，即评估已经批准的药物（单独使用或组合使用）是否可用于新目的。这往往显著减少药物上市所需的临床评估。在某种抽象层次上，药物对人体生物化学的作用，以及它们彼此之间和与其他生物分子之间的相互作用，可以建模为图。这催生了著名网络科学家 Albert-László Barabási 提出的“网络医学”概念，主张利用生物网络（如蛋白质—蛋白质相互作用与代谢通路）开发新疗法（Barabási et al.，2011）。

几何深度学习为这类方法提供了现代视角。一个早期著名例子是 Zitnik et al.（2018）的工作：他们用图神经网络预测组合疗法或多药联合治疗这一药物再定位形式的副作用，将其表述为药物—药物相互作用图中的边预测。在写作本文时仍在大范围持续的新冠疫情，激发了人们将此类方法用于对抗 COVID-19 的特殊兴趣（Gysi et al.，2020）。最后应指出，药物再定位不一定局限于合成分子：Veselkov et al.（2019）将类似方法应用于食物中含有的类药分子；如前所述，许多植物性食物含有肿瘤治疗所用化合物的生物类似物。本文一位作者参与的合作又为这一研究增添了创意：与一位分子料理厨师合作，基于富含这类类药分子的“超级食品”食材设计新颖食谱。

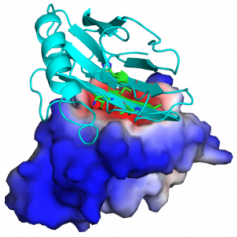
蛋白质生物学 既然已经提到蛋白质作为药物靶标，我们不妨多花一点时间讨论这个主题。蛋白质可谓最重要的生物分子之一，在体内具有无数功能，包括抵御病原体（抗体）、为皮肤提供结构（胶原蛋白）、向细胞运输氧气（血红蛋白）、催化化学反应（酶）以及信号传递（许多激素是蛋白质）。从化学上说，蛋白质是一种生物聚合物，即由称为氨基酸的小构件组成的链，在静电力影响下折叠成复杂的三维结构。正是这一结构赋予蛋白质功能，因此它对于理解蛋白质如何工作、发挥什么作用至关重要。[2]由于蛋白质是常见的药物治疗靶标，制药行业对该领域有浓厚兴趣。

蛋白质生物信息学中典型的问题层次，是从蛋白质序列（由 20 种不同氨基酸组成的字母表上的一维字符串）到三维结构（称为“蛋白质折叠”的问题），再到功能（“蛋白质功能预测”）。近期方法如 Senior et al.（2020）的 DeepMind AlphaFold 使用接触图表示蛋白质结构。Gligorijevic et al.（2020）表明，将图神经网络用于这类图可以比纯序列方法获得更好的功能预测。

Gainza et al.（2020）开发了一套名为 MaSIF 的几何深度学习流程，从蛋白质三维结构预测蛋白质之间的相互作用。MaSIF 将蛋白质建模为离散化成网格的分子表面，认为这种表示有利于处理相互作用，因为它允许抽象掉内部折叠结构。该架构基于网格卷积神经网络，作用于小型局部测地块中预先计算的化学和几何特征。网络使用蛋白质数据库中数千个蛋白质共晶三维结构训练，以处理界面预测、配体分类和对接等多个任务，并允许从头设计原则上可能作为抗癌生物免疫治疗药物的蛋白质：这类蛋白质被设计为抑制程序性细胞死亡蛋白复合物（PD-1/PD-L1）各部分之间的蛋白质—蛋白质相互作用，使免疫系统能够攻击肿瘤细胞。

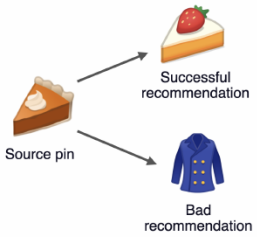
推荐系统与社交网络 图表示学习最早广为人知的大规模应用出现在社交网络中，主要是在推荐系统背景下。推荐系统负责决定向用户提供哪些内容，可能取决于用户先前在服务中的交互历史。这通常通过链接预测目标实现：监督各节点（内容条目）的嵌入，使被认为相关的条目（例如经常被一起查看）保持彼此接近。两个嵌入的接近程度（例如内积）可解释为它们在内容图中由边连接的概率；因此，对用户查询的任意内容，一种方法可以提供嵌

[2]一个常见比喻可追溯到诺贝尔化学奖得主 Emil Fischer 的 Schlüssel-Schloss-Prinzip（“钥匙—锁原理”，1894）：两种蛋白质通常只有在几何和化学结构互补时才会相互作用。



肿瘤治疗靶标 PD-L1 的蛋白质表面（热图表示预测结合位点）及所设计的结合物（以带状图表示）。

入空间中的 k 个最近邻。



从源内容出发的成功推荐与不佳推荐示意。

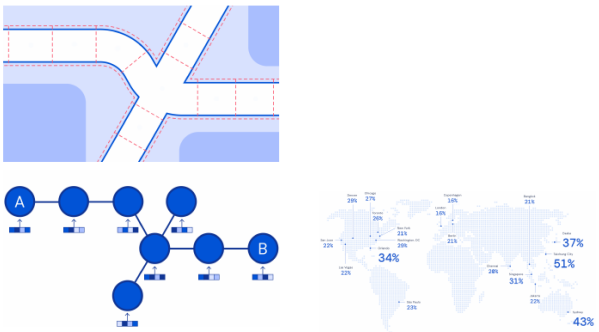
该方法的先驱之一是美国图片分享与社交媒体公司 Pinterest：除展示了 GNN 最早成功投入生产的案例之一，他们的方法 PinSage 还成功将图表示学习扩展到具有数百万节点和数十亿条边的图（Ying et al., 2018）。[3]相关应用，尤其是产品推荐领域，随后很快出现。当前投入生产的流行 GNN 推荐系统包括阿里巴巴的 Aligraph（Zhu et al., 2019）和亚马逊的 P-Companion（Hao et al., 2020）。这样，图深度学习每天都在影响数百万人。

在社交网络内容分析背景下，另一个值得注意的工作是 Fabula AI，它是最早被收购的 GNN 初创公司之一（2019 年被 Twitter 收购）。这家由本文一位作者及其团队创立的公司开发了检测社交网络错误信息的新技术（Monti et al., 2019）。Fabula 的方案将某条新闻的传播建模为分享它的用

[3]Pinterest 还提出了后续工作 PinnerSage（Pal et al., 2020），将用户特定的上下文信息有效融入推荐系统。

户组成的网络：如果一位用户转发了另一位用户的信息，或者他们在社交网络上相互关注，就将他们连接起来。然后把这一图输入图神经网络，将整个图分类为“真实”或“虚假”内容；标签依据事实核查机构的一致意见确定。除显示较强且很快趋于稳定的预测能力（往往在新闻传播数小时内）外，对单个用户节点嵌入的分析还揭示了倾向于分享不正确信息的用户明显聚类，体现出著名的“回音室”效应。

交通预测 交通网络是几何深度学习技术已经对全球数十亿用户产生实际影响的另一领域。例如，在道路网络中，可以将交叉路口视为节点，将连接路口的道路段视为边；随后可以用道路长度、当前或历史路段速度等作为边的特征。



左：道路网络（上）及其对应的图表示（下）。右：GNN 在 Google Maps 中提供查询服务的部分大都市区域，以及所示预测质量相对改善（悉尼等城市超过 40%）。

这一领域的一个标准预测问题是预计到达时间（ETA）：对给定候选路线，提供通过它所需的预期行程时间。这不仅对面向用户的交通推荐应用必不可少，也对外卖或网约车等在运营中利用这些预测的企业非常重要。

图神经网络在这一领域同样显示出巨大前景：例如，可以直接预测道路网络相关子图的 ETA，这实际上是图回归任务。DeepMind 成功利用这种方法，得到基于 GNN 的 ETA 预测器；在写作时它已部署到 Google Maps 的生产环境（Derrow-Pinion et al.，2021），在全球多个主要大都市区域提供 ETA 查询。百度地图团队也观察到类似收益，其出行时间预测目前由

ConSTGAT 模型提供，而该模型基于图注意力网络的时空变体（Fang et al.，2020）。

物体识别 计算机视觉中机器学习技术的一个主要基准，是对给定图像中的中心物体分类的能力。ImageNet 大规模视觉识别挑战赛（Russakovsky et al.，2015，ILSVRC）曾是一项年度物体分类挑战，推动了几何深度学习的许多早期发展。ImageNet 要求模型将从网络抓取的真实图像划分为 1000 个类别之一：这些类别既多样（涵盖生物和非生物），又具体（许多类别专门区分不同品种的猫和狗）。因此，在 ImageNet 上表现良好通常意味着能够从一般照片中扎实地提取特征，这为利用预训练 ImageNet 模型的各种迁移学习设定奠定了基础。



ImageNet 中可能出现的一张示例输入图像，代表“虎斑猫”类别。

卷积神经网络在 ImageNet 上的成功——特别是 Krizhevsky 等（2012）的 AlexNet 模型以很大优势横扫 ILSVRC 2012——在很大程度上推动了深度学习整体在学术界和工业界的采用。此后 CNN 始终在 ILSVRC 中名列前茅，催生了 VGG-16（Simonyan and Zisserman，2014）、Inception（Szegedy et al.，2015）和 ResNet（He et al.，2016）等流行架构，它们在这项任务中成功超过人类水平。[4]这些架构使用的设计决策与正则化技术，例如修正线性激活（Nair and Hinton，2010）、dropout（Srivastava et al.，2014）、跳

[4]有趣的是，VGG-16 架构具有 16 个卷积层，被作者称为“非常深”。后续发展很快将此类模型扩展到数百甚至数千层。

跃连接（He et al.，2016）和批归一化（Ioffe and Szegedy，2015），构成了如今许多有效 CNN 模型的骨干。

与物体分类同时，物体检测也取得重大进展：即分离图像中所有感兴趣的物体，并给它们标注类别。这一任务与从图像描述到自动驾驶汽车的各种下游问题相关。由于预测需要定位，它需要更细粒度的方法；平移等变模型因而往往在这一领域证明了自身价值。有影响力的例子包括 R-CNN 系列模型（Girshick et al.，2014；Girshick，2015；Ren et al.，2015；He et al.，2017）；在相关的语义分割领域，Badrinarayanan et al.（2017）的 SegNet 模型也产生了影响，其编码器—解码器架构依赖 VGG-16 骨干。

博弈 每当观测状态可以表示在网格定义域上时，卷积神经网络也会在强化学习（RL）环境中作为平移不变特征提取器发挥重要作用；例如从像素学习玩电子游戏就是如此。在这种情形下，CNN 负责将输入压缩为展平后的向量表示，再用它推导驱动 RL 智能体行为的策略函数或价值函数。虽然强化学习的具体细节不是本节重点，但我们注意到过去十年深度学习的一些最有影响力成果来自 CNN 支持的强化学习。

一个特别值得提及的例子是 DeepMind 的 AlphaGo（Silver et al.，2016）。它对表示当前落子位置的 19×19 网格应用 CNN，编码一局围棋的当前状态。随后，通过结合对以往专家棋步的学习、蒙特卡洛树搜索和自我对弈，它成功达到足以在一场受到全球广泛报道的五局挑战赛中战胜李世石的围棋水平；李世石是有史以来最强的围棋选手之一。



围棋在 19×19 棋盘上进行，两名棋手在空位放置黑白棋子。合法状态数估计约为 2×10^{170}（Tromp and Farnebäck，2006），远多于宇宙中的原子数。

虽然这已是更广泛人工智能领域的重要里程碑——围棋的状态空间比

国际象棋等游戏复杂得多——AlphaGo 的发展并未止步。作者逐渐从架构中移除越来越多的围棋特定偏置：AlphaGo Zero 移除人类偏置，完全通过自我对弈优化（Silver et al.，2017）；AlphaZero 将该算法扩展到国际象棋和将棋等相关双人游戏；最后，MuZero（Schrittwieser et al.，2020）引入一个能够即时学习游戏规则的模型，从而无需预先了解规则，也能在 Atari 2600 游戏机以及围棋、国际象棋和将棋中达到很强的表现。在这些发展过程中，CNN 一直是模型输入表示的骨干。

多年来人们为 Atari 2600 平台提出了若干高性能强化学习智能体（Mnih et al.，2015，2016；Schulman et al.，2017），但长期以来它们无法在该平台提供的全部 57 款游戏上达到人类水平。Agent57（Badia et al.，2020）最终打破这一障碍；它使用一个参数化策略族，从强探索到纯利用不等，并在训练不同阶段以不同方式确定其优先级。它的大部分计算同样由应用于视频游戏帧缓冲区的 CNN 驱动。

文本与语音合成 除自然映射到二维网格的图像外，（几何）深度学习的一些最突出成功也发生在一维网格上。自然的例子是文本和语音，它们将几何深度学习蓝图带入自然语言处理、数字信号处理等不同领域。

这一领域应用最广、宣传最多的一些工作聚焦于合成：无条件地或以特定提示为条件生成语音或文本。这种设定可支持许多有用任务，例如文本转语音（TTS）、预测文本补全和机器翻译。过去十年提出了多种用于文本与语音生成的神经架构，最初主要基于循环神经网络，例如前述 seq2seq 模型（Sutskever et al.，2014）或循环注意力（Bahdanau et al.，2014）；但近年来它们逐渐被卷积神经网络和基于 Transformer 的架构替代。

简单一维卷积在此设定下的一个特殊局限是感受野线性增长，需要许多层才能覆盖迄今生成的序列。相比之下，空洞卷积以相同数量的参数提供指数增长的感受野。[5]因此它们成为非常强的替代方案，在机器翻译中最终达到可与 RNN 竞争的表现（Kalchbrenner et al.，2016）；同时由于能够跨所有输入位置并行，大幅降低计算复杂度。[6]空洞卷积最著名的应用是 van den Oord et al.（2016a）的 WaveNet 模型。WaveNet 表明，利用空洞结构可以

[5]空洞卷积也称为 à trous 卷积，法语字面意思是“有孔的”卷积。

[6]此类技术也曾在蛋白质—蛋白质相互作用等多样问题上超过 RNN（Deac et al.，2019）。

在原始波形层面合成语音（通常每秒 16000 个或更多样本），所产生的语音样本比此前最好的文本转语音系统显著更“像人”。[7]

随后人们进一步表明，WaveNet 的计算可以蒸馏到简单得多的 WaveRNN 模型（Kalchbrenner et al.，2018）中，而这一模型使该技术能够有效地以工业规模部署。这不仅允许为 Google Assistant 等服务进行大规模语音生成，也允许高效的设备端计算，例如使用端到端加密的 Google Duo。

Transformer（Vaswani et al.，2017）成功超越循环和卷积架构的局限，表明自注意力足以在机器翻译中达到最先进的表现。随后，它们彻底改变了自然语言处理。借助 BERT（Devlin et al.，2018）等模型提供的预训练嵌入，Transformer 计算得以用于大量自然语言处理下游应用；例如，Google 使用 BERT 嵌入支持其搜索引擎。

过去几年 Transformer 最广为宣传的应用或许是文本生成，主要由 OpenAI 的生成式预训练 Transformer 模型家族推动（GPT；Radford et al.（2018，2019）；Brown et al.（2020））。特别是 GPT-3（Brown et al.，2020）成功将语言模型学习扩展到 1750 亿个可学习参数，并在从网络抓取的海量文本语料上训练下一个词预测。这不仅使它成为能处理多种语言任务的强大少样本学习器，也使它成为能够生成连贯、听起来像人类所写文本的生成器。这种能力不仅意味着大量下游应用，也引发了广泛媒体报道。

医疗健康　医学领域的应用是几何深度学习另一个有前景的方向。这些方法的使用方式多种多样。首先，CNN 等较传统的架构已应用于网格结构数据，例如预测重症监护病房住院时长（Rocheteau et al.，2020），或从视网膜扫描诊断威胁视力的疾病（De Fauw et al.，2018）。Winkels and Cohen（2019）表明，与传统 CNN 相比，使用三维旋转—平移群卷积网络可以提高肺结节检测的准确率。

其次，将器官建模为几何曲面后，网格卷积神经网络被证明能够处理多种任务，从利用遗传相关信息重建面部结构（Mahdi et al.，2020），到大脑皮层分区（Cucurull et al.，2018），再到根据皮层表面结构回归人口统计属性（Besson et al.，2020）。后两个例子体现出神经科学中一个日益增长的趋

[7]此外，WaveNet 模型也被证明能够生成钢琴曲。

势：将大脑视为具有复杂褶皱、产生高度非欧几里得结构的曲面。[8]

与此同时，神经科学家常常尝试构造和分析大脑功能网络，表示执行某种认知功能时共同激活的不同脑区。这些网络通常使用功能磁共振成像（fMRI）构造，后者实时显示大脑哪些区域消耗了更多血液。[9]功能网络既可以揭示患者的人口统计信息（例如区分男性和女性；Arslan et al.（2018）），也可用于神经病理诊断，这是我们希望强调的几何深度学习在医学中的第三个应用方向。在此背景下，Ktena et al.（2017）率先使用图神经网络预测自闭症谱系障碍等神经系统状况。大脑的几何与功能结构似乎密切相关，Itani and Thanou（2021）近期指出，在神经疾病分析中联合利用二者具有益处。

第四，患者网络在基于机器学习的医学诊断中日益受到重视。这些方法的依据是：患者在人口统计、基因型和表型方面的相似信息可以改善疾病预测。Parisot et al.（2018）将图神经网络应用于根据人口统计特征构建的患者网络，进行神经疾病诊断，表明使用图可以改善预测结果。Cosmo et al.（2020）展示了这一设定下潜在图学习的好处，即网络学习一个未知的患者图。后一项工作使用了 UK Biobank 的数据，这是一个包括脑成像在内的大规模医疗数据集合（Miller et al.，2016）。

电子健康记录（EHR）中可以找到大量住院患者数据。EHR 分析不仅能全面展现患者病程，还允许将相似患者联系起来。这与诊断中常用的模式识别方法一致：临床医生利用经验识别临床特征模式；当医生的经验能使其快速诊断病情时，这可能是主要方法。[10]沿着这一思路，若干工作尝试基于 EHR 数据构建患者图，方式包括分析医生笔记的嵌入（Malone et al.，2018）、入院诊断相似性（Rocheteau et al.，2021），甚至假定完全连接图（Zhu and Razavian，2019）。所有这些情况都给出了支持使用图表示学习处理 EHR 的有前景结果。

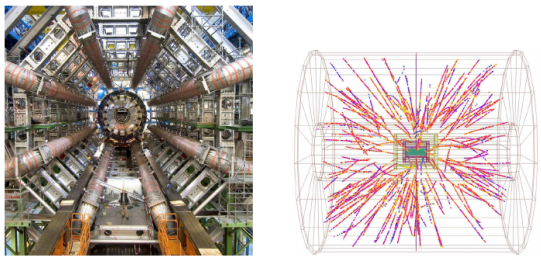
粒子物理与天体物理 高能物理学家或许是自然科学领域中最早采用图神经网络这一新工具的专家之一。Shlomi et al.（2020）在近期综述中指出，机

[8]在解剖学文献中，大脑皮层的这些结构称为脑沟和脑回。

[9]通常使用血氧水平依赖（BOLD）对比成像。

[10]公开可用的匿名重症监护 EHR 数据集包括 MIMIC-III（Johnson et al.，2016）和 eICU（Pollard et al.，2018）。

器学习在粒子物理实验中长期得到大量使用：或是学习复杂的逆函数，以便根据探测器测得的信息推断底层物理过程，或是执行分类和回归任务。对于后者，为使用 CNN 等标准深度学习架构，过去常常不得不强行将数据放入网格等不自然的表示中。然而，物理学中的许多问题涉及具有丰富关系和相互作用的无序集合形式的数据，可以自然地表示为图。



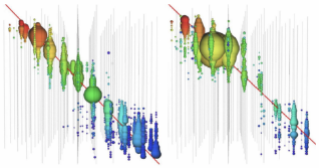
左：大型强子对撞机探测器的一部分。右：粒子喷注示例。

高能物理的一个重要应用是重建和分类粒子喷注：它们是来自单个初始事件的粒子经过多次连续相互作用和衰变后产生的稳定粒子簇射。在欧洲核子研究中心（CERN）建造的最大、最著名的粒子加速器——大型强子对撞机中，这类喷注是质子以接近光速碰撞的结果。这些碰撞产生有质量的粒子，例如长期寻求的希格斯玻色子或顶夸克。识别和分类碰撞事件至关重要，因为它可能为新粒子的存在提供实验证据。

近期提出了多种用于粒子喷注分类的几何深度学习方法，例如 Komiske et al.（2019）和 Qu and Gouskos（2019）分别基于 DeepSet 与 Dynamic Graph CNN 架构。最近，人们也有兴趣开发由物理考虑推导的专门架构，纳入与哈密顿或拉格朗日力学一致的归纳偏置（例如 Sanchez-Gonzalez et al.（2019）；Cranmer et al.（2020））、对洛伦兹群（物理中时空的一种基本对称性）等变（Bogatskiy et al.，2020），甚至纳入符号推理（Cranmer et al.，2019），并能够从数据学习物理定律。这类方法更具可解释性，因此被领域专家认为更“可信”，并且具有更好的泛化能力。

除粒子加速器外，天体物理学家如今也使用粒子探测器进行多信使天文学：一种协同观测来自同一来源的不同信号的新方式，这些信号包括电磁辐射、引力波和中微子。中微子天文学尤其令人感兴趣，因为中微子与物质极

少发生相互作用，因而可以传播极远距离而几乎不受影响。探测中微子可以观测光学望远镜无法触及的对象，但需要尺寸巨大的探测器——IceCube 中微子天文台使用南极点一立方千米的南极冰架作为探测器。探测高能中微子可能有助于揭示宇宙中一些最神秘的对象，例如耀变体和黑洞。Choma et al.（2018）使用几何神经网络对 IceCube 中微子探测器的不规则几何建模，在探测来自天体物理源的中微子并将其与背景事件分离方面表现显著更好。



IceCube 探测器中背景事件（左，缪子束）和天体物理中微子事件（右，高能单缪子）的特征性光沉积分布。Choma et al.（2018）。

虽然中微子天文学为研究宇宙提供了巨大希望，传统光学和射电望远镜仍是天文学家的“主力”。使用这些传统仪器时，几何深度学习仍可为数据分析提供新方法。例如，Scaife and Porter（2021）使用旋转等变 CNN 分类射电星系；McEwen et al.（2021）使用球面 CNN 分析宇宙微波背景辐射——这一大爆炸遗迹可能有助于揭示原初宇宙的形成。如前所述，这类信号自然表示在球面上，等变神经网络是研究它们的适当工具。

虚拟现实与增强现实 另一类推动大量几何深度学习方法发展的应用是计算机视觉和图形学，特别是处理虚拟现实和增强现实中的三维人体模型。用于制作《阿凡达》等电影特效的动作捕捉技术通常分两步：首先，将三维扫描仪捕获的演员身体或面部动作输入与某个标准形状建立对应；该标准形状通常建模为离散流形或网格，此问题常称为“分析”。其次，生成一个重复输入动作的新形状，称为“合成”。计算机图形学和视觉中早期的几何深度学习工作（Masci et al.，2015；Boscaini et al.，2016a；Monti et al.，2017）开发了网格卷积神经网络来解决分析问题，更具体地说，是可形变形状对应问题。

Litany et al.（2018）和 Ranjan et al.（2018）独立提出了首批用于三

维形状合成的几何自编码器架构。在这些架构中，假定已知一个身体、面部或手部的标准网格，合成任务是回归节点的三维坐标；用微分几何术语说，就是曲面的嵌入。Kulon et al.（2020）展示了一套三维手部姿态估计的混合流程，使用基于图像 CNN 的编码器和几何解码器。该系统与英国初创公司 Ariel AI 合作开发并在 CVPR 2020 展示的演示，能够在手机上从视频输入以快于实时的速度创建具有完全可活动手部的逼真人体化身。Ariel AI 于 2020 年被 Snap 收购，在写作时，其技术用于 Snap 的增强现实产品。



从真实环境中的二维图像重建复杂三维手部姿态的例子(Kulon et al.，2020)。

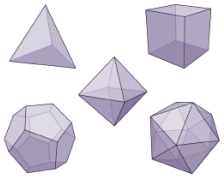
第七章　历史视角

译者说明：本章关于最先、当前、尚未审查及未来会议的叙述均对应冻结的 2021 年原稿时点；未将其改写为当前学术史或性能结论。

“对称性，无论你将它的意义定义得多宽或多窄，都是人类历经时代努力理解和创造秩序、美与完美时所凭借的一个观念。”这一略带诗意的对称性定义出自伟大数学家赫尔曼 · 外尔的同名著作（Weyl，2015）；这是他从普林斯顿高等研究院退休前夕的天鹅之歌。外尔将对称性在科学和艺术中占据的特殊地位追溯到古代，从苏美尔人的对称图案到毕达哥拉斯学派——后者认为圆因其旋转对称性而完美。柏拉图认为，今天以他的名字命名的五种正多面体极为基本，以至于必定是构成物质世界的基本积木。虽然人们认为柏拉图创造了“συμμετρία”一词（字面意思为“相同的度量”），他只是含糊地用它来传达艺术中比例之美和音乐中的和谐。天文学家兼数学家约翰内斯 · 开普勒首次尝试严格分析冰晶的对称形状。在《六角雪花论》中，他将雪花的六重二面体结构归因于粒子的六角密堆积；这一思想早于人们清晰认识物质的形成方式，如今仍是晶体学的基础（Ball，2011）。[1]

数学与物理中的对称性　在现代数学中，对称性几乎无一例外地以群论语言表达。群论的起源通常归功于埃瓦里斯特 · 伽罗瓦，他在 19 世纪 30 年代创造了这一术语，并用它研究多项式方程的可解性。另外两位与群论相关的人物是索菲斯 · 李和费利克斯 · 克莱因；他们曾相识并共同开展了一段富有成果的工作（Tobies，2019）。前者发展了如今以其名字命名的连续对称性理

[1]这本小册子的完整标题是 *Strena, Seu De Nive Sexangula*（“新年礼物，或六角雪花论”）。正如标题所示，开普勒于 1611 年将其作为圣诞礼物送给他的赞助人兼朋友 Johannes Matthäus Wackher von Wackenfels。



四面体、立方体、八面体、十二面体和二十面体称为柏拉图立体。

论；后者在我们于本文开头提及的埃尔朗根纲领中，宣称群论是几何的组织原则。黎曼几何被明确排除在克莱因统一的几何图景之外，又过了五十年才被纳入，这主要归功于埃利 · 嘉当在 20 世纪 20 年代的工作。

克莱因在哥廷根的同事埃米 · 诺特证明，物理系统作用量的每一个可微对称性都有一个对应的守恒定律（Noether，1918）。这在物理学中是一个惊人的结果：此前，人们需要通过细致的实验观察才能发现能量守恒之类的基本定律；即便如此，它仍只是一个不知从何而来的经验结果。诺特定理——诺贝尔奖得主弗兰克 · 维尔切克称之为 “20 和 21 世纪物理学的一颗指路星”——表明能量守恒源自时间的平移对称性。这是一个相当直观的想法：实验结果不应取决于实验是在今天还是明天进行。

与电荷守恒相联系的对称性是电磁场的全局规范不变性，它最早出现在麦克斯韦的电动力学表述中（Maxwell，1865），但其重要性起初未被注意到。在著作中热情赞颂对称性的同一位赫尔曼 · 外尔，于 20 世纪初首次在物理学中引入了规范不变性的概念，强调它作为可从中推导电磁学的原理的作用。[2]几十年后，这一基本原理——以杨和米尔斯（1954）发展的推广形式——才成功提供了统一框架，描述电磁力、弱力和强力的量子力学行为，最终发展为涵盖除引力以外所有自然界基本力的标准模型。因此，我们可以同另一位诺贝尔奖得主菲利普 · 安德森（1972）一道得出结论：“说物理学是对称性之学，只是稍稍夸张了一点。”

[2]外尔在 1919 年首先猜想（但并不正确），尺度或 “规范” 的改变下的不变性是电磁学的一种局域对称性。“规范”，德语为 Eich，一词是类比铁路的不同轨距而选用的。量子力学发展之后，外尔（1929）修改了规范的选择，将尺度因子替换为波的相位变化。参见 Straumann (1996)。

对称性在机器学习中的早期应用 在机器学习及其在模式识别和计算机视觉中的应用中，对称性的重要性早已得到认识。Amari（1978）、Kanatani（2012）和 Lenz（1990）开展了为模式识别设计等变特征检测器的早期工作。[3]在神经网络文献中，Minsky and Papert（2017）著名的感知机群不变性定理对（单层）感知机学习不变量的能力给出了基本限制。这是研究多层架构的主要动机之一（Sejnowski et al.，1986；Shawe-Taylor，1989，1993），最终催生了深度学习。

在神经网络界，Neocognitron（Fukushima and Miyake，1982）被认为是首次在神经网络中实现平移不变性，以进行“不受位置平移影响的模式识别”。其解决方案是一种具有局部连接的层级神经网络，灵感来自神经科学家 David Hubel 和 Torsten Wiesel 二十年前在视觉皮层中发现的感受野（Hubel and Wiesel，1959）。[4]这些思想在 Yann LeCun 及其合作者的开创性工作中发展为卷积神经网络（LeCun et al.，1998）。最早从表示论视角研究不变和等变神经网络的是 Wood and Shawe-Taylor（1996），遗憾的是这项工作很少被引用。这些思想较新的体现包括 Makadia et al.（2007）、Esteves et al.（2020）和本文作者之一的工作（Cohen and Welling，2016）。

图神经网络 很难确切指出图神经网络的概念何时开始出现：部分原因是早期大多数工作没有将图置于核心地位，部分原因是 GNN 直到 2010 年代后期才变得实用，还有一部分原因是这一领域由若干研究方向汇合而成。尽管如此，图神经网络的早期形式至少可追溯到 20 世纪 90 年代，例如 Alessandro Sperduti 的 Labeling RAAM（Sperduti，1994）、Goller and Kuchler（1996）的“通过结构反向传播”，以及对数据结构的自适应处理（Sperduti and Starita，1997；Frasconi et al.，1998）。尽管这些工作主要关注对“结构”（通常是树或有向无环图）进行操作，其架构中保持的许多不变性令人联想到如今更常用的 GNN。

对一般图结构处理的首次适当研究（以及“图神经网络”一词的创造）

[3]Shun’ ichi Amari 被认为创立了信息几何领域，该领域将黎曼几何模型应用于概率。信息几何研究的主要对象是统计流形，其中每一点对应一个概率分布。

[4]这项经典工作获得了 1981 年诺贝尔医学奖，Hubel 和 Wiesel 与 Roger Sperry 分享了该奖。

出现在 21 世纪之交以后。意大利锡耶纳大学人工智能实验室中，由 Marco Gori 和 Franco Scarselli 主导的论文提出了首个 “GNN”（Gori et al.，2005；Scarselli et al.，2008）。[5]这些模型依赖循环机制，要求神经网络参数指定压缩映射，并因而通过搜索不动点计算节点表示——这本身需要一种特殊形式的反向传播（Almeida，1990；Pineda，1988），并且完全不依赖节点特征。Li et al.（2015）的门控 GNN（GGNN）模型解决了上述所有问题。GGNN 将现代循环神经网络的诸多优点，例如门控机制（Cho et al.，2014）和通过时间反向传播，带入 GNN 模型，至今仍然流行。

计算化学 还须特别指出 GNN 的另一条独立且同时发展的路线：它完全由计算化学的需求驱动，其中分子最自然地表示为原子（节点）通过化学键（边）连接而成的图。这促使人们设计直接作用于此类图结构、用于预测分子性质的计算技术；这些技术已于 20 世纪 90 年代出现在机器学习中，包括 Kireev（1995）的 ChemNet 模型和 Baskin et al.（1997）的工作。令人瞩目的是，Merkwirth and Lengauer（2005）的 “分子图网络” 早在 2005 年就明确提出了当代 GNN 常见的许多要素，如以边类型为条件的权重和全局池化。化学的动机继续推动 GNN 在 2010 年代的发展，两个重要进展分别侧重于改进小分子的分子指纹（Duvenaud et al.，2015）和预测其量子化学性质（Gilmer et al.，2017）。在本文写作时，分子性质预测是 GNN 最成功的应用之一，在新抗生素药物的虚拟筛选中取得了有影响的结果（Stokes et al.，2020）。

节点嵌入 图上深度学习最早的一些成功案例，是基于图结构以无监督方式学习节点表示。由于其结构上的启发，这一方向也提供了图表示学习和网络科学两个群体之间最直接的联系之一。该领域关键的早期方法依赖基于随机游走的嵌入：学习节点表示，使在短随机游走中共同出现的节点具有更接近的表示。代表性方法包括 DeepWalk（Perozzi et al.，2014）、node2vec（Grover and Leskovec，2016）和 LINE（Tang et al.，2015），它们均为纯自监督方法。Planetoid（Yang et al.，2016）是这一领域首个在监督标签信息

[5]与此同时，Alessio Micheli 提出了图神经网络模型 NN4G，该模型侧重于前馈而非循环范式（Micheli，2009）。

可用时将其纳入的方法。

人们曾多次尝试将随机游走目标与 GNN 编码器统一起来，代表性方法包括变分图自编码器（VGAE, Kipf and Welling（2016b））、嵌入传播（García-Durán and Niepert，2017）以及 GraphSAGE 的无监督变体（Hamilton et al.，2017）。然而结果好坏参半，人们很快发现，将相邻节点表示拉近本已是 GNN 归纳偏置的一个关键部分。事实上，研究表明，在节点特征可用的设定中，未训练的 GNN 已表现出足以与 DeepWalk 竞争的性能（Veličković et al.，2019；Wu et al.，2019）。[6]这催生了一个新方向：不再将随机游走目标与 GNN 结合，而是转向受互信息最大化启发、并与图像领域成功方法相呼应的对比方法。该方向的重要例子包括 Deep Graph Infomax（DGI, Veličković et al.（2019））、GRACE（Zhu et al.，2020）、类 BERT 目标（Hu et al.，2020）和 BGRL（Thakoor et al.，2021）。

概率图模型 图神经网络同时也通过嵌入概率图模型（PGM，Wainwright and Jordan（2008））的计算而重新兴起。PGM 是处理图数据的有力工具，其效用源于对图的边采取概率视角：节点被视为随机变量，图结构编码条件独立性假设，从而可以显著简化联合分布的计算和采样。事实上，许多支持 PGM 学习和推断的算法（精确或近似）都依赖于沿其边传递消息的形式（Pearl，2014），例如变分平均场推断和有环置信传播（Yedidia et al.，2001；Murphy et al.，2013）。

PGM 与消息传递的这种联系随后发展成 GNN 架构，structure2vec 的作者建立了早期理论联系（Dai et al.，2016）。具体而言，通过将图表示学习设定表述为马尔可夫随机场（其节点对应输入特征和潜在表示），作者将平均场推断和有环置信传播的计算直接对应到与当今常用 GNN 类似的模型。

使 GNN 的潜在表示与 PGM 所维持的概率分布联系起来的关键“技巧”是使用分布的希尔伯特空间嵌入（Smola et al.，2007）。给定适当选取的特征 x 的嵌入函数 ϕ，可以将其概率分布 $p(x)$ 嵌入为期望嵌入 $\mathbb{E}_{x\sim p(x)}\phi(x)$。这种对应允许我们进行类似 GNN 的计算，同时知道 GNN 计算出的表示总

[6]近期 Srinivasan and Ribeiro（2019）提出了一个理论框架，证明结构表示与位置表示的等价性。此外，Qiu et al.（2018）表明，所有基于随机游走的嵌入技术都等价于一个适当设定的矩阵分解任务。

是对应于节点特征上某个概率分布的嵌入。

structure2vec 模型本身最终是一种很容易纳入本书框架的 GNN 架构，但它的设定启发了一系列更直接地结合 PGM 中计算的 GNN 架构。新近的例子已成功将 GNN 与条件随机场（Gao et al., 2019; Spalević et al., 2020）、关系马尔可夫网络（Qu et al., 2019）及马尔可夫逻辑网络（Zhang et al., 2020）结合。

Weisfeiler–Lehman 形式体系 随着图神经网络重新兴起，人们随即着力理解其基本局限，尤其是表达能力方面的局限。尽管 GNN 逐渐被证明是图结构数据的强大建模工具，显然，它们并不能完美解决图上指定的所有任务。一个典型例子是判定图同构：我们的 GNN 能否为给定的两个不同构图赋予不同表示？[7]这一框架有两个用处：若 GNN 无法做到这一点，那么它就无法胜任任何需要区分这两个图的任务；此外，目前尚不知图同构判定是否属于复杂度类 P，而 GNN 的计算通常全部属于该类。[8]

将 GNN 与图同构联系起来的关键框架是 Weisfeiler–Lehman（WL）图同构测试（Weisfeiler and Leman，1968）。该测试通过沿图的边迭代传递节点特征，再对各邻域内的和进行随机哈希，生成图表示。它与随机初始化的卷积 GNN 的联系显而易见，并且很早就被观察到，例如在 Kipf and Welling（2016a）的 GCN 模型中。除此之外，WL 迭代此前已由 Shervashidze et al.（2011）引入图核领域，至今仍是整图表示无监督学习的强大基线。

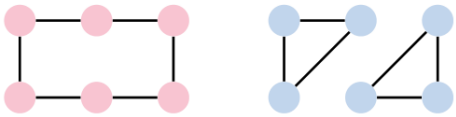
尽管 WL 测试在概念上很简单，也有许多它无法区分的不同构图的简单例子，其表达能力终究与 GNN 密切相关（见下图）。Morris et al.（2019）和 Xu et al.（2018）的分析都得出了一个惊人的结论：符合第 5.3 节中所述三种类型之一的任何 GNN，其能力都不会超过 WL 测试！

为了恰好达到这一表示能力，GNN 更新规则必须满足某些约束。Xu et al.（2018）表明，在离散特征域中，GNN 使用的聚合函数必须是单射，求和是一个重要代表。[9]根据其分析结果，Xu et al.（2018）提出图同构网络

[7]由于置换不变性，GNN 会为两个同构图赋予相同的表示，因此这一情形可以直接解决。

[8]目前已知最好的图同构判定算法由 Babai and Luks（1983）提出；不过 Babai（2016）最近提出的方案（尚未完全审查）意味着存在准多项式时间解法。

[9]取最大值和取平均值等常用聚合器在这方面有所不足，因为它们无法区分例如邻居多重



一个简单例子：WL 测试不能区分六节点环和两个三角形。源 PDF 第 124 页（原 120）的侧图。

（GIN），这是该框架下表达能力最大的 GNN 的一个简单而强大的例子。它也可以用我们提出的卷积型 GNN 表达。

最后值得注意的是，这些结果不能推广到连续节点特征空间。事实上，Corso et al.（2020）利用 Borsuk–Ulam 定理（Borsuk，1933）证明，在假设节点特征为实值时，获得单射聚合函数需要多个聚合器，具体数量等于接收节点的度。[10]他们的发现促成了主邻域聚合（PNA）架构，该架构提出一种在经验上强大且稳定的多聚合器 GNN。

高阶方法 前几段的结果并不与 GNN 的实际效用矛盾。事实上，在许多现实应用中，输入特征足够丰富，即使存在上述局限，也能支持图结构上有用的判别计算。[11]不过，一个关键推论是，GNN 检测图内某些基本结构的能力相对较弱。针对 WL 测试的具体局限或失败案例，若干工作提出了可证明比 WL 测试更强的 GNN 变体，因而可能有助于需要检测此类结构的任务。[12]

寻找表达能力更强的 GNN，最直接的地方或许就是 WL 测试本身。事实上，可以考虑一个 WL 测试的层级来增强原始 WL 测试：k-WL 测试为节点的 k 元组赋予表示（Morris et al.，2017）。Morris et al.（2019）将 k-WL 测试直接转化为高阶 k-GNN 架构，可以证明它比我们先前考虑的 GNN 类型更强。然而，由于需要维护元组表示，实际中很难扩展到 $k > 3$。[13]

与此同时，Maron et al.（2018，2019）研究了定义在节点 k 元组上的

集 $\{\{a, b\}\}$ 和 $\{\{a, a, b, b\}\}$。

[10]这种聚合器的一个例子是邻居多重集的各阶矩。

[11]相比之下，上述分析几乎总是考虑无特征或具有类别特征的图。

[12]一个重要例子是计算化学，其中分子的化学功能可能受到其分子图中芳香环存在与否的强烈影响。

[13]已有工作尝试稀疏化 k-GNN 的计算，例如 δ-k-LGNN（Morris et al.，2020）。

不变和等变图网络的刻画。除了证明任何不变或等变图网络都可表示为有限个生成元的线性组合——其数量只依赖于 k——这一令人惊讶的结果外，作者还表明这些层的表达能力等价于 k-WL 测试，并提出了一种在经验上可扩展、可证明达到 3-WL 能力的变体。

除推广计算表示所处的定义域外，人们还投入大量精力分析 1-WL 的具体失败案例，并增强 GNN 输入以帮助区分这些案例。一个常见方法是为节点附加识别特征，以帮助检测结构。相关提议包括独热表示（Murphy et al., 2019）以及纯随机特征（Sato et al., 2020）。[14]更广泛地说，已有许多工作试图通过调整消息函数或计算所依托的图，将结构信息纳入消息传递过程。若干有趣的研究路线包括采样锚节点集合（You et al., 2019）、基于拉普拉斯特征向量聚合（Stachenfeld et al., 2020; Beaini et al., 2020; Dwivedi and Bresson, 2020），以及进行拓扑数据分析，用于位置嵌入（Bouritsas et al., 2020）或驱动消息传递（Bodnar et al., 2021）。[15]

信号处理与调和分析 自卷积神经网络早期取得成功以来，研究者借助调和分析、图像处理和计算神经科学的工具，尝试给出解释其效率的理论框架。M 理论是由 Tomaso Poggio 及其合作者开创的、受视觉皮层启发的框架（Riesenhuber and Poggio, 1999; Serre et al., 2007），基于可在某些对称群下变换的模板概念。计算神经科学中产生的另一个重要模型是 Simoncelli and Freeman（1995）开发的可转向金字塔，这是一种对某些输入变换具有良好性质的多尺度小波分解。它们是早期纹理生成模型（Portilla and Simoncelli, 2000）的核心要素；此后通过将可转向小波特征替换为深度 CNN 特征改进了这些模型（Gatys et al., 2015）。最后，由 Stéphane Mallat（2012）引入并由 Bruna and Mallat（2013）发展的散射变换，通过用多尺度小波分解替代可训练滤波器，提供了理解 CNN 的框架，同时展示了形变稳定性及架构中深度的作用。

[14]例如，如果一个节点在 k 跳外看到了自己的标识符，就直接表明它处于一个 k 环中。

[15]在计算化学中，通常假定分子功能由子结构（官能团）驱动；这些子结构直接启发了在模体层面对分子建模。参考文献包括 Jin et al.（2018, 2020）和 Fey et al.（2020）。

图与网格上的信号处理 另一类重要的图神经网络通常称为谱方法，源于本文作者之一的工作（Bruna et al.，2013），使用了图傅里叶变换的概念。这一构造植根于信号处理和计算调和分析领域；在 2000 年代后期和 2010 年代初，处理非欧信号在这些领域日益受到重视。Pierre Vandergheynst 团队（Shuman et al.，2013）与 José Moura 团队（Sandryhaila and Moura，2013）的重要论文普及了“图信号处理”（GSP）概念，以及基于图邻接矩阵和拉普拉斯矩阵特征向量的傅里叶变换推广。Defferrard et al.（2016）和 Kipf and Welling（2016a）基于谱滤波器的图卷积神经网络是该领域被引用最多的工作之一，或可认为它们重新激发了近年来对图上机器学习的兴趣。

值得注意的是，在计算机图形学和几何处理领域，非欧调和分析比图信号处理至少早十年出现。流形和网格上的谱滤波器可追溯到 Taubin et al.（1996）的工作。继 Karni and Gotsman（2000）关于谱几何压缩及 Lévy（2006）关于使用拉普拉斯特征向量作为非欧傅里叶基的影响深远的论文之后，这些方法在 2000 年代成为主流。谱方法已用于多种应用，其中最突出的是构造形状描述符（Sun et al.，2009）和函数映射（Ovsjanikov et al.，2012）；在写作时这些方法仍广泛用于计算机图形学。[16]

计算机图形学与几何处理 计算机图形学和几何处理领域的多位作者提出了基于内禀度量不变量的形状分析模型（Elad and Kimmel，2003；Mémoli and Sapiro，2005；Bronstein et al.，2006），本文一位作者在其早期著作中深入讨论了这些模型（Bronstein et al.，2008）。同一领域还探索了内禀对称性的概念（Raviv et al.，2007；Ovsjanikov et al.，2008）。首个网格深度学习架构——测地线 CNN——由本文一位作者所在团队开发（Masci et al.，2015）。该模型将共享权重的局部滤波器应用于测地线径向局部块；它是后来由本文另一位作者开发的规范等变 CNN 的一种特殊情形（Cohen et al.，2019）。同一团队的 Federico Monti et al.（2017）提出了具有可学习聚合操作的测地线 CNN 推广 MoNet，使用类似注意力的机制处理网格的局部结构特征，并展示了它也适用于一般图。本文另一位作者提出了图注意力网络（GAT，Veličković et al.，2018），严格来说，它可以视为 MoNet 的一个特

[16]Roee Litman 和 Alex Bronstein（2013）提出了与谱图 CNN 类似的可学习形状描述符；后者是本文作者的双胞胎兄弟。

例。GAT 将 MoNet 的注意力机制推广为同时纳入节点特征信息，突破了先前工作中完全由结构决定相关性的做法。它是目前最流行的 GNN 架构之一。

在计算机图形学的背景下，还值得一提的是，集合学习（Zaheer et al., 2017）的思想同时在斯坦福 Leo Guibas 团队中以 PointNet（Qi et al., 2017）的名称得到发展，用于分析三维点云。该架构催生了许多后续工作，包括本文一位作者提出的动态图 CNN（DGCNN, Wang et al.（2019b））。DGCNN 使用最近邻图捕捉点云局部结构，使节点之间能够交换信息；这一架构的关键特征是图按需构建，并在神经网络层之间根据下游任务更新。后一性质使 DGCNN 成为“潜在图学习”最早的体现之一，后者又产生了大量后续工作。对 DGCNN 的 k 近邻图方案的扩展包括通过双层优化（Franceschi et al., 2019）、强化学习（Kazi et al., 2020）或直接监督（Veličković et al., 2020）对图的边进行更明确的控制。另一条独立的变分路线通过 NRI 模型出现，该模型从计算得到的后验分布中按概率采样边（Kipf et al., 2018）。尽管它仍依赖节点数的二次计算量，却允许明确编码所选边的不确定性。

在未给定图的情况下进行图上学习，另一个非常流行的方向是对完全图执行 GNN 式计算，让网络自己推断如何利用连通性。这一需求尤其出现在自然语言处理中：句子中的不同词以高度非平凡且非顺序的方式相互作用。在词的完全图上操作催生了 Transformer 模型的首次实现（Vaswani et al., 2017）；它取代循环和卷积模型成为神经机器翻译的最先进方法，引发了大量相关工作，超越了自然语言处理与其他领域的界限。全连接 GNN 计算也同时出现在仿真（Battaglia et al., 2016）、推理（Santoro et al., 2017）及多智能体（Hoshen, 2017）应用中；当节点数合理地较小时，它仍是流行选择。

算法推理 本节讨论的大多数例子涉及由空间诱导的几何，进而形成底层定义域及其不变性和对称性。然而，计算环境中也存在大量不变性和对称性的例子。与几何深度学习中许多常见设定的一个重要区别是，连接不再需要编码任何形式的相似性、邻近性或关系类型；它们仅仅指定所连接数据点之间数据流的“配方”。

相应地，神经网络的计算模仿算法的推理过程（Cormen et al., 2009），

另有由算法控制流和中间结果诱导的不变性。在算法领域，所假定的输入不变量通常称为前置条件，而算法保持的不变量称为后置条件。[17]顾名思义，算法推理研究方向（Cappart et al.，2021，第 3.3 节）旨在产生适当保持算法不变量的神经网络架构。该领域研究过通用神经计算机的构造，例如神经图灵机（Graves et al.，2014）和可微神经计算机（Graves et al.，2016）。虽然这类架构具有通用计算的所有特征，但它们同时引入了若干组件，往往难以优化；实践中，简单的关系推理器（例如 Santoro et al.（2017，2018）提出的模型）几乎总能超过它们。

由于复杂后置条件难以建模，许多关于学习执行的归纳偏置的工作（Zaremba and Sutskever，2014）集中于基本算法（例如简单算术）。该领域的重要例子包括神经 GPU（Kaiser and Sutskever，2015）、神经 RAM（Kurach et al.，2015）、神经程序员–解释器（Reed and De Freitas，2015）、神经算术逻辑单元（Trask et al.，2018；Madsen and Johansen，2020）及神经执行引擎（Yan et al.，2020）。

GNN 架构的快速发展使模拟超线性复杂度的组合算法成为可能。Xu et al.（2019）开创的算法对齐框架从理论上表明，GNN 与动态规划（Bellman，1966）对齐，而大多数算法都可以用动态规划这一语言表达。与此同时，本文一位作者以经验方式展示，实践中可以设计并训练与算法不变量对齐的 GNN（Veličković et al.，2019）。此后，人们实现了与迭代算法（Tang et al.，2020）、线性对数复杂度算法（Freivalds et al.，2019）、数据结构（Veličković et al.，2020）及持久记忆（Strathmann et al.，2021）的对齐。这类模型也已实际用于隐式规划器（Deac et al.，2020），进入强化学习算法领域。

与此同时，使用 GNN 进行物理仿真也取得重大进展（Sanchez-Gonzalez et al.，2020；Pfaff et al.，2020）。这一方向对于设计能够泛化的 GNN 给出了许多相同建议。这种对应是可以预期的：算法可以表述为离散时间仿真，而仿真通常以逐步算法实现，因此两个方向都需要保持相似类型的不变量。

外推的衡量与算法推理研究紧密相连。这是神经网络一个众所周知的难点，因为它们的大部分成功案例都发生在分布内泛化时，即训练数据中发现

[17]例如，Bellman–Ford 寻路算法（Bellman，1958）的一个不变量是：在 k 步之后，它总会计算出至源节点使用不超过 k 条边的最短路径。

的模式恰当地预示了测试数据中的模式。然而，算法不变量必须保持，与输入的大小或生成分布等无关，这意味着训练集很可能无法覆盖实践中遇到的所有可能情形。Xu et al.（2020b）对使用整流激活函数且能够外推的 GNN 应满足的要求提出了一个几何论证：需要设计其组件和特征化方式，使各个组成模块（例如消息函数）仅学习线性目标函数。Bevilacqua et al.（2021）提出从因果推理的视角观察外推，从而得到环境不变的图表示。

几何深度学习 最后的历史评述涉及本文自身的名称。“几何深度学习”一词最初由本文一位作者于 2015 年在其欧洲研究委员会（ERC）资助项目中提出，并通过同名的 *IEEE Signal Processing Magazine* 论文得到普及（Bronstein et al., 2017）。那篇论文尽管“带有一些谨慎”，仍宣告了“一个新领域正在诞生”的迹象。鉴于图神经网络近期的流行、不变性和等变性思想在广泛机器学习应用中的日益使用，以及我们正在撰写本文这一事实本身，或许可以认为这一预言至少部分实现了。“4G：网格、图、群和规范”（Grids, Graphs, Groups, and Gauges）这一名称由 Max Welling 为 ELLIS 几何深度学习项目创造，该项目由本文两位作者共同主持。诚然，最后一个“G”有些牵强，因为底层结构是流形和丛，而不是规范。对于本文，我们又加上一个“G”——测地线（Geodesics），指代流形的度量不变量和内禀对称性。

致谢

本文是一次微薄的尝试，旨在通过不变性和对称性的几何视角，总结和综合数十年来有关深度学习架构的已有知识。我们希望，我们的视角既能帮助初学者和实践者更容易地了解这一领域，也能帮助研究者按照我们的蓝图综合出新的架构。某种意义上，我们希望呈现“构建那些你所需要的全部架构所需要的一切”——这是受 Vaswani et al.（2017）启发的一语双关。

本文大部分内容写于 2020 年末和 2021 年初。正如常有的情况，我们曾无数次怀疑整个图景是否有意义，并借助同事们提供的机会克服“怯场”，展示工作的早期版本。这些版本在 Petar 于剑桥的报告（承蒙 Pietro Liò 帮助）以及 Michael 于牛津（承蒙 Xiaowen Dong 帮助）和帝国理工学院（由 Michael Huth 和 Daniel Rueckert 主持）的报告中得以面世。承蒙 Andreas Maier 友好邀请，Petar 还得以在埃尔朗根–纽伦堡大学——埃尔朗根纲领的诞生地！——介绍我们的工作。这些报告收到的反馈对于鼓舞我们的士气和进一步完善工作都极其宝贵。最后，同样重要的是，我们感谢 ICLR 2021 组委会；我们的工作将在该会议上由 Michael 作主题报告。

我们应当指出，融汇如此大量的研究很少仅凭四个人的专业知识便能做到。因此，我们要向所有在本文发展过程中仔细研究其各个方面，并向我们提供认真意见和参考文献的研究者致以应有的感谢：Yoshua Bengio、Charles Blundell、Andreea Deac、Fabian Fuchs、Francesco di Giovanni、Marco Gori、Raia Hadsell、Will Hamilton、Maksym Korablyov、Christian Merkwirth、Razvan Pascanu、Bruno Ribeiro、Anna Scaife、Jürgen Schmidhuber、Marwin Segler、Corentin Tallec、Ngân Vũ、Peter Wirnsberger 和 David Wong。他们的专业反馈对于巩固我们的统一工作、使其对各个细分领域更有用极其宝贵。当然，本文中的任何不妥之处均由我们独自负责。目前这仍然是一项进行中的工作，我们非常乐意在任何阶段收到意见。如果您发现任何错误或遗漏，请与我们联系。

附录 A　原文疑点与适用条件提示

译者提示。本附录整理对冻结的 2021 年原稿的审校发现，不属于原书正文。下列页码均为 160 页源 PDF 的物理页码（原书印刷页码通常比它少 4）；节号与式号沿用正文。正文保留原稿的公式和主张，只有明确的翻译、转录及排版问题作了修订。本附录指出应核对的符号、假设和论证范围，不另补证明，也不将尚未回溯原始文献的概括认证为定理。

第 1–2 章：高维学习

源 PDF 10–13，§2.1–2.2。 普适逼近、Sobolev 光滑性与逼近率的叙述须指定定义域、函数类和误差拓扑。源文旁注中的 $2s+1$ 指数及 $\epsilon^{-d/s}$ 的“速率”应结合其引用理解，不能脱离参数量与误差的关系使用。三次样条二阶导数平方积分对一般函数给出半范数；最小范数梯度下降还依赖初值、步长及问题结构。图 2 的采样尺度论证也隐含定义域、采样分布及覆盖条件。

第 3 章：几何先验

源 PDF 13、15–18，§3.1。 内积空间还需完备性才能称为 Hilbert 空间；连续定义域上的信号还需可积性等限制。源文的群作用定义应连同单位元及复合条件理解。正三角形的旋转生成元在源文写成 60°，而图中三角形的旋转对称性对应 120° 的整倍数。

源 PDF 21–26，§3.2–3.3。 图的边成员应属于边集，源文一处写为节点集。不同定义域间的同构集合一般不能直接当成同一对象的自同构群。

Gromov–Hausdorff 距离的最小失真表述还需说明对应关系及通常的 1/2 因子。源 PDF 26 旁注的图对齐目标写作最小化 $\operatorname{trace}(AP\widetilde{A}P^{\top})$；这一符号不能直接用作通常的邻接匹配目标，应回查所引 QAP 定义。

源 PDF 23–31，§3.3–3.4。 源文将形变映射与位移场都记为 τ，其梯度及平移特例应区别。作用 $\rho(\tau)x = x \circ \tau^{-1}$、$\tau(u) = u - v$ 与后续平移 Fourier 相位的方向约定并不完全一致。小波稳定性界、尺度分离及 $O(1)$ 的描述需要相应信号、滤波器、尺度和形变假设；连续 Fourier “基” 也有广义本征函数及积分意义的限制。

源 PDF 31–34，§3.5。 群平均除以 $\mu(\mathfrak{G})$ 需要有限 Haar 体积；非紧平移群不能直接如此归一化。逐点非线性的等变性取决于通道上的群作用，不能从标量情形推广到任意表示。池化、定义域粗化和网络普适性还须满足对应群作用的兼容条件。

第 4 章：几何定义域

源 PDF 35–39，§4.1。 15 个生成元的结论涉及二阶输入、输出张量的线性置换等变映射，不能忽略输入与输出的张量阶数。源文若将等变输出称为 “相同”，应按置换后对应理解。均值向量、复制矩阵及局部聚合中的对象类型也应区分。

源 PDF 40–48，§4.2–4.3。 正交归一化离散 Fourier 变换下，卷积定理有相应的归一化因子。连续谱论证须区分联合平移本征函数、单个位移算子及广义函数。源 PDF 47 将 $SE(3)$ 称为三维特殊正交群，混淆了 $SO(3)$ 与六维刚体运动群 $SE(3)$。群卷积与相关的正负号、Haar 测度、核存在性及可积条件也须采用同一约定。

源 PDF 48–51，§4.4 的流形和微分。 流形的局部欧几里得结构、向量场作为导子及嵌入的叙述采取直观写法；严格使用时需补齐光滑性、线性及定义域条件。图 11 图注中重复出现的 “任意 $\mathbf{x}, \mathbf{x}$” 沿用源文，相关内积实际涉及两个切向量。局部体积元的坐标表达应与基变换及积分测度一并理解。

源 PDF 52–55，§4.4 的测地线和输运。 Levi–Civita 测地线通常只在局部最短。仅保持一个向量的长度及其与曲线速度的夹角，不能在一般高维流形上唯一确定平行移动，还需联络方程。源 PDF 53 的 $\Gamma_{u\to v}$ 值域重复为 $T_u\Omega$ 并接有 $T_v\Omega$，记号不整齐。Hopf–Rinow 结论以连通、无边界等通常条件为背景。推前与拉回旁注中的余向量所在空间及对偶配对，也应按映射的源、目标区分。

源 PDF 56–59，§4.4 的谱分析。 通常的散度与梯度的负伴随关系，和源文正算子 $\Delta = \nabla^*\nabla$ 的约定需要区分；“邻域均值减中心”及欧氏 $+d^2/du^2$ 脚注与正算子符号不一致。离散谱与自伴性需紧致性及适当边界条件，特征函数还需归一化。Laplace 基的最优性是相应函数类的最坏误差意义，不能理解为对每个信号都优于任何其他基；重根的特征基也有选择歧义。

源 PDF 59–60，§4.4 的空间卷积。 局部支撑、单射半径、体积元及标架约定会影响卷积表达。非平行化并不普遍意味着连单个处处非零向量场也不存在；S^2 的毛球例子不能直接推广到所有非平行化流形。以梯度构造标架的稳定性还需避开奇点或不稳定方向。

源 PDF 61–65，§4.5。 RGB 例子先写 $\mathbf{y}' = \rho_{\text{out}}(\mathfrak{g})\mathbf{y}$，其同段推导却得到逆表示；后续向量卷积段的输运方向、坐标场的逆元也不完全一致，应统一主动或被动变换约定。二阶张量的左右作用依张量类型而定。独立规范下“核必须为零”的结论还需区分非平凡表示、平凡分量以及局部项。

源 PDF 65–68，§4.6 的网格拉普拉斯。 面集不是仅由所有三角闭合团自动决定的。式 (25) 的面积归一化余切算子一般形如 $M^{-1}L$，通常并非在普通欧氏内积下对称，须用质量内积或相应对称化。随后仅以边长写权重的表达式又未带前式的面积因子；正谱与正交特征展开须跟随同一约定。网格细化收敛还需质量条件，源文的 Schwarz 灯笼旁注提示了这一限制。

源 PDF 69，§4.6 的谱滤波。 有理滤波器的分辨率独立性、线性近似复

杂度、指数衰减及扰动稳定性均依赖滤波器、谱尺度和精度等条件，不能由“有理函数”这一形式单独保证。

源 PDF 70–71，§4.6 的函数映射。 一般 $n' \times n$ 函数映射不是 $O(n)$ 的元素。面积保持的离散形式需要质量矩阵；矩形 $C^\top C = I$ 不保证双侧可逆。任意正交共轭也不自动对应实际重网格化。源文的 $\mathbf{F}(Q) = V\mathbf{F}(\Lambda)$ 还须对特征向量符号、重根及相应稳定子施加兼容限制。

第 5 章：模型

源 PDF 73–78，§5.1。 有限网格边界、零填充及下采样会限制严格平移等变性。非线性本身不产生全局不变性，池化也需要适当群作用。残差层的 Euler 类比需同维状态、时间步和粗化操作的条件；数据增强的样本复杂度比较限于所引理论设定。

源 PDF 78–81，§5.2。 源文把 24 个纯旋转记为 O_h，而这一记号通常还含反射、共有 48 个元素；纯旋转群通常记为 O。源文方向通道段将方向写作 $\mathfrak{k}$ 而非 $\mathfrak{h}$，三维例子后给出的 $W \times H \times C$ 存储维度也未体现深度。DNA 例子的变换需包含通道互补。非交换群 $SO(3)$ 的 Fourier 卷积一般涉及矩阵乘积，而非普通逐元素乘积。

源 PDF 83–84，§5.3。 用仅依赖节点特征的注意力查找表表示任意边常数，需要节点或结构可辨识信息；相同特征不自动区分不同的边权。softmax 的归一化还依赖整个邻域。各类 GNN 的内存、训练难度和同配图上的优劣是具体方法与数据下的比较。

源 PDF 85–86，§5.4。 完全图的共享聚合对每个节点相同，但仍能携带集合的全局信息，因此不能仅以“所有节点相同”为由将该输入忽略。Deep Sets 与 PointNet 的普适性通常还需要聚合或全局上下文，而不只是逐点映射。标准正弦位置编码的频率通常依通道而非节点位置；它与有限循环网格 DFT 的联系也不宜当成逐项相等。

源 PDF 87–90，§5.5。 坐标是 $E(3)$ 作用空间中的点，不是该群的元素；平移是仿射作用。消息传递的等变性还依赖邻域选择和标量权重等条

件。Wigner 矩阵块的叙述针对旋转表示，不能无条件用于整个非紧旋转平移群；不可约表示理论本身不限于紧群。早期模型的等变特征与不变预测应分别辨明。

源 PDF 90–93，§5.6。 极坐标积分应配合体积元和离散面积权重理解。源 PDF 91 的局部块公式中，权重函数与求和的位置本身不整齐，分母还可能为零；译文按源保留。n 个离散方向通道的精确循环置换只直接适用于 C_n 的离散转角。Laplacian 的局部各向同性也不等于一般曲面上每个非局部谱核都无方向依赖。

源 PDF 96–98，§5.7。 式 (39) 左乘列向量时 W 的形状应与输入、输出匹配，源文却写为 $k \times m$。压缩映射不动点定理需要完备空间及自映射，有限步“相等”通常只可近似实现。梯度链还含循环权重的 Jacobian，不能只由激活函数导数判断；ReLU 也不普遍消除梯度消失，输出无界不单独推出梯度爆炸。

源 PDF 101–104，§5.8。 式 (49) 的一阶近似在取 $\delta = 1$ 后，被式 (50) 写成精确导数；后续还混用 $\tau(t+1)$ 与 $\tau(t)+1$。时间规整类不变性与门控形式的推导应放在相应连续近似和采样条件下理解。单调可微映射不自动是自同构；$\tau' = 1$ 也允许常量平移。时间膨胀不普遍等于离散插零，未知规整导数是否能由当前输入、状态识别还需假设。向量门也不对应单个标量时间变换。

源 PDF 104，§5.8 的初始化。 门值区间中的 T_m 在源文未定义；非线性函数的期望一般不等于期望的函数值，亦即

$$\mathbb{E}[\mathrm{logistic}(Z)] \neq \mathrm{logistic}(\mathbb{E}Z)$$

通常成立，不能把二者直接等同。chrono 初始化中应区分更新门 Γ 与遗忘门的互补关系；脚注中的时间重标度还要满足允许的门值范围。

第 6 章：应用及第 7 章：历史

源 PDF 106–118，第 6 章。 企业部署、性能提升及医学潜力均为 2021 原稿的叙述，不表示当前部署状态或获批疗效。源文关于阿司匹林与

柳树皮、fMRI 血液消耗、VGG-16“十六个卷积层”及 IceCube“冰架”的表达有简化或不准确之处；例如模型总层数与卷积层数、南极点大陆冰与冰架需区别。嵌入内积也需配合概率链接函数才能解释为概率；MuZero 的环境模型与“学会规则”的说法须区分。

源 PDF 119–120，第 7 章的 Noether 与规范对称性。 守恒律与对称性的联系有作用量及动力学条件；电荷守恒须区别物质场的全局 $U(1)$、局域规范冗余及电磁场本身的变换。早期规范理论的历史概括仍依源文保留。

源 PDF 121–125，第 7 章的 GNN、概率模型与 WL。 最初 GNN 是否完全不依赖节点特征、任意概率图模型嵌入更新是否对应有效概率分布，须回查其具体模型。WL 结论依初始标签、消息传递类型及聚合的单射性等条件；有限生成元的线性层结论不能直接推广成任意非线性网络的形式。连续聚合器的个数也与特征维度、连续性和最大度相关。源文“在 k 跳后看到自身标识符即表示 k 环”的旁注还需排除回溯游走。

源 PDF 128–130，第 7 章的算法推理。 算法保持的循环不变量与终止后置条件并非同义。多数算法可用动态规划表达、架构与算法对齐以及外推的表述，应保留其特定理论或经验范围；整流网络的线性外推条件不表示任意目标都能外推。前言中的创立者姓名 Eilenber 沿用源拼写，未据外部资料改名。

参考文献

译者说明：以下保留原文书目的语种和出版信息，B001–B340 为本译稿检索定位符，逐条源页见工程内书目清单；未据外部数据库更新元数据。

[B001] Yonathan Aflalo and Ron Kimmel. Spectral multidimensional scaling. PNAS, 110(45):18052–18057, 2013.

[B002] Yonathan Aflalo, Haim Brezis, and Ron Kimmel. On the optimality of shape and data representation in the spectral domain. SIAM J. Imaging Sciences, 8(2):1141–1160, 2015.

[B003] Luis B Almeida. A learning rule for asynchronous perceptrons with feedback in a combinatorial environment. In Artificial neural networks: concept learning, pages 102–111. 1990.

[B004] Uri Alon and Eran Yahav. On the bottleneck of graph neural networks and its practical implications. arXiv:2006.05205, 2020.

[B005] Sl Amari. Feature spaces which admit and detect invariant signal transformations. In Joint Conference on Pattern Recognition, 1978.

[B006] Brandon Anderson, Truong-Son Hy, and Risi Kondor. Cormorant: Covariant molecular neural networks. arXiv:1906.04015, 2019.

[B007] Philip W Anderson. More is different. Science, 177(4047):393–396, 1972.

[B008] Mathieu Andreux, Emanuele Rodola, Mathieu Aubry, and Daniel Cremers. Anisotropic Laplace-Beltrami operators for shape analysis. In ECCV, 2014.

[B009] Salim Arslan, Sofia Ira Ktena, Ben Glocker, and Daniel Rueckert. Graph saliency maps through spectral convolutional networks: Application to sex

classification with brain connectivity. In Graphs in Biomedical Image Analysis and Integrating Medical Imaging and Non-Imaging Modalities, pages 3–13. 2018.

[B010] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. arXiv:1607.06450, 2016.

[B011] László Babai. Graph isomorphism in quasipolynomial time. In ACM Symposium on Theory of Computing, 2016.

[B012] László Babai and Eugene M Luks. Canonical labeling of graphs. In ACM Symposium on Theory of computing, 1983.

[B013] Francis Bach. Breaking the curse of dimensionality with convex neural networks. JMLR, 18(1):629–681, 2017.

[B014] Adrià Puigdomènech Badia, Bilal Piot, Steven Kapturowski, Pablo Sprechmann, Alex Vitvitskyi, Zhaohan Daniel Guo, and Charles Blundell. Agent57: Outperforming the atari human benchmark. In ICML, 2020.

[B015] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. Segnet: A deep convolutional encoder-decoder architecture for image segmentation. Trans. PAMI, 39(12):2481–2495, 2017.

[B016] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. arXiv:1409.0473, 2014.

[B017] Philip Ball. In retrospect: On the six-cornered snowflake. Nature, 480(7378): 455–455, 2011.

[B018] Bassam Bamieh. Discovering transforms: A tutorial on circulant matrices, circular convolution, and the discrete fourier transform. arXiv:1805.05533, 2018.

[B019] Stefan Banach. Sur les opérations dans les ensembles abstraits et leur application aux équations intégrales. Fundamenta Mathematicae, 3(1):133–181, 1922.

[B020] Victor Bapst, Thomas Keck, A Grabska-Barwińska, Craig Donner, Ekin Dogus Cubuk, Samuel S Schoenholz, Annette Obika, Alexander WR Nelson, Trevor Back, Demis Hassabis, et al. Unveiling the predictive power of static structure in glassy systems. Nature Physics, 16(4):448–454, 2020.

[B021] Albert-László Barabási, Natali Gulbahce, and Joseph Loscalzo. Network medicine: a network-based approach to human disease. Nature Reviews Genetics, 12(1):56–68, 2011.

[B022] Andrew R Barron. Universal approximation bounds for superpositions of a sigmoidal function. IEEE Trans. Information Theory, 39(3):930–945, 1993.

[B023] Igor I Baskin, Vladimir A Palyulin, and Nikolai S Zefirov. A neural device for searching direct correlations between structures and properties of chemical compounds. J. Chemical Information and Computer Sciences, 37(4): 715–721, 1997.

[B024] Peter W Battaglia, Razvan Pascanu, Matthew Lai, Danilo Rezende, and Koray Kavukcuoglu. Interaction networks for learning about objects, relations and physics. arXiv:1612.00222, 2016.

[B025] Peter W Battaglia, Jessica B Hamrick, Victor Bapst, Alvaro Sanchez-Gonzalez, Vinicius Zambaldi, Mateusz Malinowski, Andrea Tacchetti, David Raposo, Adam Santoro, Ryan Faulkner, et al. Relational inductive biases, deep learning, and graph networks. arXiv:1806.01261, 2018.

[B026] Dominique Beaini, Saro Passaro, Vincent Létourneau, William L Hamilton, Gabriele Corso, and Pietro Liò. Directional graph networks. arXiv:2010.02863, 2020.

[B027] Richard Bellman. On a routing problem. Quarterly of Applied Mathematics, 16 (1):87–90, 1958.

[B028] Richard Bellman. Dynamic programming. Science, 153(3731):34–37, 1966.

[B029] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. IEEE Trans. Neural Networks, 5(2):157–166, 1994.

[B030] Marcel Berger. A panoramic view of Riemannian geometry. Springer, 2012.

[B031] Pierre Besson, Todd Parrish, Aggelos K Katsaggelos, and S Kathleen Bandt. Geometric deep learning on brain shape predicts sex and age. BioRxiv:177543, 2020.

[B032] Beatrice Bevilacqua, Yangze Zhou, and Bruno Ribeiro. Size-invariant graph representations for graph classification extrapolations. arXiv:2103.05045, 2021.

[B033] Guy Blanc, Neha Gupta, Gregory Valiant, and Paul Valiant. Implicit regularization for deep neural networks driven by an ornstein-uhlenbeck like process. In COLT, 2020.

[B034] Cristian Bodnar, Fabrizio Frasca, Yu Guang Wang, Nina Otter, Guido Montúfar, Pietro Liò, and Michael Bronstein. Weisfeiler and lehman go topological: Message passing simplicial networks. arXiv:2103.03212, 2021.

[B035] Alexander Bogatskiy, Brandon Anderson, Jan Offermann, Marwah Roussi, David Miller, and Risi Kondor. Lorentz group equivariant neural network for particle physics. In ICML, 2020.

[B036] Karol Borsuk. Drei sätze über die n-dimensionale euklidische sphäre. Fundamenta Mathematicae, 20(1):177–190, 1933.

[B037] Davide Boscaini, Davide Eynard, Drosos Kourounis, and Michael M Bronstein. Shape-from-operator: Recovering shapes from intrinsic operators. Computer Graphics Forum, 34(2):265–274, 2015.

[B038] Davide Boscaini, Jonathan Masci, Emanuele Rodoià, and Michael Bronstein. Learning shape correspondence with anisotropic convolutional neural networks. In NIPS, 2016a.

[B039] Davide Boscaini, Jonathan Masci, Emanuele Rodolà, Michael M Bronstein, and Daniel Cremers. Anisotropic diffusion descriptors. Computer Graphics Forum, 35(2):431–441, 2016b.

[B040] Sébastien Bougleux, Luc Brun, Vincenzo Carletti, Pasquale Foggia, Benoit Gaüzere, and Mario Vento. A quadratic assignment formulation of the graph edit distance. arXiv:1512.07494, 2015.

[B041] Giorgos Bouritsas, Fabrizio Frasca, Stefanos Zafeiriou, and Michael M Bronstein. Improving graph neural network expressivity via subgraph isomorphism counting. arXiv:2006.09252, 2020.

[B042] Alexander M Bronstein, Michael M Bronstein, and Ron Kimmel. Generalized multidimensional scaling: a framework for isometry-invariant partial surface matching. PNAS, 103(5):1168–1172, 2006.

[B043] Alexander M Bronstein, Michael M Bronstein, and Ron Kimmel. Numerical geometry of non-rigid shapes. Springer, 2008.

[B044] Michael M Bronstein, Joan Bruna, Yann LeCun, Arthur Szlam, and Pierre Vandergheynst. Geometric deep learning: going beyond Euclidean data. IEEE Signal Processing Magazine, 34(4):18–42, 2017.

[B045] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. arXiv:2005.14165, 2020.

[B046] Joan Bruna and Stéphane Mallat. Invariant scattering convolution networks. IEEE transactions on pattern analysis and machine intelligence, 35(8):1872–1886, 2013.

[B047] Joan Bruna, Wojciech Zaremba, Arthur Szlam, and Yann LeCun. Spectral networks and locally connected networks on graphs. In ICLR, 2013.

[B048] Quentin Cappart, Didier Chételat, Elias Khalil, Andrea Lodi, Christopher Morris, and Petar Veličković. Combinatorial optimization and reasoning with graph neural networks. arXiv:2102.09544, 2021.

[B049] Ricky TQ Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. arXiv:1806.07366, 2018.

[B050] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In ICML, 2020.

[B051] Albert Chern, Felix Knöppel, Ulrich Pinkall, and Peter Schröder. Shape from metric. ACM Trans. Graphics, 37(4):1–17, 2018.

[B052] Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. arXiv:1406.1078, 2014.

[B053] Nicholas Choma, Federico Monti, Lisa Gerhardt, Tomasz Palczewski, Zahra Ronaghi, Prabhat Prabhat, Wahid Bhimji, Michael M Bronstein, Spencer R Klein, and Joan Bruna. Graph neural networks for icecube signal classification. In ICMLA, 2018.

[B054] Taco Cohen and Max Welling. Group equivariant convolutional networks. In ICML, 2016.

[B055] Taco Cohen, Maurice Weiler, Berkay Kicanaoglu, and Max Welling. Gauge equivariant convolutional networks and the icosahedral CNN. In ICML, 2019.

[B056] Taco S Cohen, Mario Geiger, Jonas Köhler, and Max Welling. Spherical cnns. arXiv:1801.10130, 2018.

[B057] Tim Cooijmans, Nicolas Ballas, César Laurent, Çağlar Gülçehre, and Aaron Courville. Recurrent batch normalization. arXiv:1603.09025, 2016.

[B058] Etienne Corman, Justin Solomon, Mirela Ben-Chen, Leonidas Guibas, and Maks Ovsjanikov. Functional characterization of intrinsic and extrinsic geometry. ACM Trans. Graphics, 36(2):1–17, 2017.

[B059] Thomas H Cormen, Charles E Leiserson, Ronald L Rivest, and Clifford Stein. Introduction to algorithms. MIT press, 2009.

[B060] Gabriele Corso, Luca Cavalleri, Dominique Beaini, Pietro Liò, and Petar Veličković. Principal neighbourhood aggregation for graph nets. arXiv:2004.05718, 2020.

[B061] Luca Cosmo, Anees Kazi, Seyed-Ahmad Ahmadi, Nassir Navab, and Michael Bronstein. Latent-graph learning for disease prediction. In MICCAI, 2020.

[B062] Miles Cranmer, Sam Greydanus, Stephan Hoyer, Peter Battaglia, David Spergel, and Shirley Ho. Lagrangian neural networks. arXiv:2003.04630, 2020.

[B063] Miles D Cranmer, Rui Xu, Peter Battaglia, and Shirley Ho. Learning symbolic physics with graph networks. arXiv:1909.05862, 2019.

[B064] Guillem Cucurull, Konrad Wagstyl, Arantxa Casanova, Petar Veličković, Estrid Jakobsen, Michal Drozdzal, Adriana Romero, Alan Evans, and Yoshua Bengio. Convolutional neural networks for mesh-based parcellation of the cerebral cortex. 2018.

[B065] George Cybenko. Approximation by superpositions of a sigmoidal function. Mathematics of Control, Signals and Systems, 2(4):303–314, 1989.

[B066] Hanjun Dai, Bo Dai, and Le Song. Discriminative embeddings of latent variable models for structured data. In ICML, 2016.

[B067] Jeffrey De Fauw, Joseph R Ledsam, Bernardino Romera-Paredes, Stanislav Nikolov, Nenad Tomasev, Sam Blackwell, Harry Askham, Xavier Glorot, Brendan O'Donoghue, Daniel Visentin, et al. Clinically applicable deep learning for diagnosis and referral in retinal disease. Nature Medicine, 24 (9):1342–1350, 2018.

[B068] Pim de Haan, Maurice Weiler, Taco Cohen, and Max Welling. Gauge equivariant mesh CNNs: Anisotropic convolutions on geometric graphs. In NeurIPS, 2020.

[B069] Andreea Deac, Petar Veličković, and Pietro Sormanni. Attentive cross-modal paratope prediction. Journal of Computational Biology, 26(6):536–545, 2019.

[B070] Andreea Deac, Petar Veličković, Ognjen Milinković, Pierre-Luc Bacon, Jian Tang, and Mladen Nikolić. Xlvin: executed latent value iteration nets. arXiv:2010.13146, 2020.

[B071] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional neural networks on graphs with fast localized spectral filtering. NIPS, 2016.

[B072] Austin Derrow-Pinion, Jennifer She, David Wong, Oliver Lange, Todd Hester, Luis Perez, Marc Nunkesser, Seongjae Lee, Xueying Guo, Peter W Battaglia, Vishal Gupta, Ang Li, Zhongwen Xu, Alvaro Sanchez-Gonzalez, Yujia Li, and Petar Veličković. Traffic Prediction with Graph Neural Networks in Google Maps. 2021.

[B073] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv:1810.04805, 2018.

[B074] David K Duvenaud, Dougal Maclaurin, Jorge Iparraguirre, Rafael Bombarell, Timothy Hirzel, Alán Aspuru-Guzik, and Ryan P Adams. Convolutional networks on graphs for learning molecular fingerprints. NIPS, 2015.

[B075] Vijay Prakash Dwivedi and Xavier Bresson. A generalization of transformer networks to graphs. arXiv:2012.09699, 2020.

[B076] Asi Elad and Ron Kimmel. On bending invariant signatures for surfaces. Trans. PAMI, 25(10):1285–1295, 2003.

[B077] Jeffrey L Elman. Finding structure in time. Cognitive Science, 14(2):179–211, 1990.

[B078] Carlos Esteves, Ameesh Makadia, and Kostas Daniilidis. Spin-weighted spherical CNNs. arXiv:2006.10731, 2020.

[B079] Xiaomin Fang, Jizhou Huang, Fan Wang, Lingke Zeng, Haijin Liang, and Haifeng Wang. ConSTGAT: Contextual spatial-temporal graph attention network for travel time estimation at baidu maps. In KDD, 2020.

[B080] Matthias Fey, Jan-Gin Yuen, and Frank Weichert. Hierarchical inter-message passing for learning on molecular graphs. arXiv:2006.12179, 2020.

[B081] Marc Finzi, Samuel Stanton, Pavel Izmailov, and Andrew Gordon Wilson. Generalizing convolutional neural networks for equivariance to lie groups on arbitrary continuous data. In ICML, 2020.

[B082] Jon Folkman. Regular line-symmetric graphs. Journal of Combinatorial Theory, 3(3):215–232, 1967.

[B083] Luca Franceschi, Mathias Niepert, Massimiliano Pontil, and Xiao He. Learning discrete structures for graph neural networks. In ICML, 2019.

[B084] Paolo Frasconi, Marco Gori, and Alessandro Sperduti. A general framework for adaptive processing of data structures. IEEE Trans. Neural Networks, 9 (5):768–786, 1998.

[B085] Kārlis Freivalds, Emīls Ozoliņš, and Agris Šostaks. Neural shuffle-exchange networks–sequence processing in o (n log n) time. arXiv:1907.07897, 2019.

[B086] Fabian B Fuchs, Daniel E Worrall, Volker Fischer, and Max Welling. SE(3)-transformers: 3D roto-translation equivariant attention networks. arXiv:2006.10503, 2020.

[B087] Kunihiko Fukushima and Sei Miyake. Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition. In Competition and Cooperation in Neural Nets, pages 267–285. Springer, 1982.

[B088] Pablo Gainza, Freyr Sverrisson, Frederico Monti, Emanuele Rodola, D Boscaini, MM Bronstein, and BE Correia. Deciphering interaction fingerprints from protein molecular surfaces using geometric deep learning. Nature Methods, 17(2):184–192, 2020.

[B089] Fernando Gama, Alejandro Ribeiro, and Joan Bruna. Diffusion scattering transforms on graphs. In ICLR, 2019.

[B090] Fernando Gama, Joan Bruna, and Alejandro Ribeiro. Stability properties of graph neural networks. IEEE Trans. Signal Processing, 68:5680–5695, 2020.

[B091] Hongchang Gao, Jian Pei, and Heng Huang. Conditional random field enhanced graph convolutional neural networks. In KDD, 2019.

[B092] Alberto García-Durán and Mathias Niepert. Learning graph representations with embedding propagation. arXiv:1710.03059, 2017.

[B093] Leon A Gatys, Alexander S Ecker, and Matthias Bethge. Texture synthesis using convolutional neural networks. arXiv preprint arXiv:1505.07376, 2015.

[B094] Thomas Gaudelet, Ben Day, Arian R Jamasb, Jyothish Soman, Cristian Regep, Gertrude Liu, Jeremy BR Hayter, Richard Vickers, Charles Roberts, Jian Tang, et al. Utilising graph machine learning within drug discovery and development. arXiv:2012.05716, 2020.

[B095] Felix A Gers and Jürgen Schmidhuber. Recurrent nets that time and count. In IJCNN, 2000.

[B096] Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. arXiv:1704.01212, 2017.

[B097] Ross Girshick. Fast R-CNN. In CVPR, 2015.

[B098] Ross Girshick, JeffDonahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In CVPR, 2014.

[B099] Vladimir Gligorijevic, P Douglas Renfrew, Tomasz Kosciolek, Julia Koehler Leman, Daniel Berenberg, Tommi Vatanen, Chris Chandler, Bryn C Taylor, Ian M Fisk, Hera Vlamakis, et al. Structure-based function prediction using graph convolutional networks. bioRxiv:786236, 2020.

[B100] Christoph Goller and Andreas Kuchler. Learning task-dependent distributed representations by backpropagation through structure. In ICNN, 1996.

[B101] Ian J Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks. arXiv:1406.2661, 2014.

[B102] Marco Gori, Gabriele Monfardini, and Franco Scarselli. A new model for learning in graph domains. In IJCNN, 2005.

[B103] Alex Graves. Generating sequences with recurrent neural networks. arXiv:1308.0850, 2013.

[B104] Alex Graves, Greg Wayne, and Ivo Danihelka. Neural turing machines. arXiv:1410.5401, 2014.

[B105] Alex Graves, Greg Wayne, Malcolm Reynolds, Tim Harley, Ivo Danihelka, Agnieszka Grabska-Barwińska, Sergio Gómez Colmenarejo, Edward Grefenstette, Tiago Ramalho, John Agapiou, et al. Hybrid computing using a neural network with dynamic external memory. Nature, 538(7626):471–476, 2016.

[B106] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, et al. Bootstrap your own latent: A new approach to self-supervised learning. arXiv:2006.07733, 2020.

[B107] Mikhael Gromov. Structures métriques pour les variétés riemanniennes. Cedic, 1981.

[B108] Aditya Grover and Jure Leskovec. node2vec: Scalable feature learning for networks. In KDD, 2016.

[B109] Suriya Gunasekar, Blake E Woodworth, Srinadh Bhojanapalli, Behnam Neyshabur, and Nati Srebro. Implicit regularization in matrix factorization. In NIPS, 2017.

[B110] Deisy Morselli Gysi, Ítalo Do Valle, Marinka Zitnik, Asher Ameli, Xiao Gan, Onur Varol, Helia Sanchez, Rebecca Marlene Baron, Dina Ghiassian, Joseph Loscalzo, et al. Network medicine framework for identifying drug repurposing opportunities for COVID-19. arXiv:2004.07229, 2020.

[B111] Will Hamilton, Zhitao Ying, and Jure Leskovec. Inductive representation learning on large graphs. In NIPS, 2017.

[B112] Junheng Hao, Tong Zhao, Jin Li, Xin Luna Dong, Christos Faloutsos, Yizhou Sun, and Wei Wang. P-companion: A principled framework for diversified complementary product recommendation. In Information & Knowledge Management, 2020.

[B113] Moritz Hardt and Tengyu Ma. Identity matters in deep learning. arXiv:1611.04231, 2016.

[B114] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In CVPR, 2016.

[B115] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In CVPR, 2017.

[B116] Claude Adrien Helvétius. De l'esprit. Durand, 1759.

[B117] R Devon Hjelm, Alex Fedorov, Samuel Lavoie-Marchildon, Karan Grewal, Phil Bachman, Adam Trischler, and Yoshua Bengio. Learning deep representations by mutual information estimation and maximization. In ICLR, 2019.

[B118] Sepp Hochreiter. Untersuchungen zu dynamischen neuronalen Netzen. PhD thesis, Technische Universität München, 1991.

[B119] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. Neural Computation, 9(8):1735–1780, 1997.

[B120] Kurt Hornik. Approximation capabilities of multilayer feedforward networks. Neural Networks, 4(2):251–257, 1991.

[B121] Yedid Hoshen. Vain: Attentional multi-agent predictive modeling. arXiv:1706.06122, 2017.

[B122] Weihua Hu, Bowen Liu, Joseph Gomes, Marinka Zitnik, Percy Liang, Vijay Pande, and Jure Leskovec. Strategies for pre-training graph neural networks. In ICLR, 2020.

[B123] David H Hubel and Torsten N Wiesel. Receptive fields of single neurones in the cat's striate cortex. J. Physiology, 148(3):574–591, 1959.

[B124] Michael Hutchinson, Charline Le Lan, Sheheryar Zaidi, Emilien Dupont, Yee Whye Teh, and Hyunjik Kim. LieTransformer: Equivariant self-attention for Lie groups. arXiv:2012.10885, 2020.

[B125] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In ICML, 2015.

[B126] Haris Iqbal. Harisiqbal88/plotneuralnet v1.0.0, December 2018. URL https://doi.org/10.5281/zenodo.2526396.

[B127] Sarah Itani and Dorina Thanou. Combining anatomical and functional networks for neuropathology identification: A case study on autism spectrum disorder. Medical Image Analysis, 69:101986, 2021.

[B128] Wengong Jin, Regina Barzilay, and Tommi Jaakkola. Junction tree variational autoencoder for molecular graph generation. In ICML, 2018.

[B129] Wengong Jin, Regina Barzilay, and Tommi Jaakkola. Hierarchical generation of molecular graphs using structural motifs. In ICML, 2020.

[B130] Alistair EW Johnson, Tom J Pollard, Lu Shen, H Lehman Li-Wei, Mengling Feng, Mohammad Ghassemi, Benjamin Moody, Peter Szolovits, Leo Anthony Celi, and Roger G Mark. Mimic-iii, a freely accessible critical care database. Scientific Data, 3(1):1–9, 2016.

[B131] Michael I Jordan. Serial order: A parallel distributed processing approach. In Advances in Psychology, volume 121, pages 471–495. 1997.

[B132] Chaitanya Joshi. Transformers are graph neural networks. The Gradient, 2020.

[B133] Rafal Jozefowicz, Wojciech Zaremba, and Ilya Sutskever. An empirical exploration of recurrent network architectures. In ICML, 2015.

[B134] Łukasz Kaiser and Ilya Sutskever. Neural GPUs learn algorithms. arXiv:1511.08228, 2015.

[B135] Nal Kalchbrenner, Lasse Espeholt, Karen Simonyan, Aaron van den Oord, Alex Graves, and Koray Kavukcuoglu. Neural machine translation in linear time. arXiv:1610.10099, 2016.

[B136] Nal Kalchbrenner, Erich Elsen, Karen Simonyan, Seb Noury, Norman Casagrande, Edward Lockhart, Florian Stimberg, Aaron van den Oord, Sander Dieleman, and Koray Kavukcuoglu. Efficient neural audio synthesis. In ICML, 2018.

[B137] Ken-Ichi Kanatani. Group-theoretical methods in image understanding. Springer, 2012.

[B138] Zachi Karni and Craig Gotsman. Spectral compression of mesh geometry. In Proc. Computer Graphics and Interactive Techniques, 2000.

[B139] Anees Kazi, Luca Cosmo, Nassir Navab, and Michael Bronstein. Differentiable graph module (DGM) graph convolutional networks. arXiv:2002.04999, 2020.

[B140] Henry Kenlay, Dorina Thanou, and Xiaowen Dong. Interpretable stability bounds for spectral graph filters. arXiv:2102.09587, 2021.

[B141] Ron Kimmel and James A Sethian. Computing geodesic paths on manifolds. PNAS, 95(15):8431–8435, 1998.

[B142] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. arXiv:1412.6980, 2014.

[B143] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. arXiv:1312.6114, 2013.

[B144] Thomas Kipf, Ethan Fetaya, Kuan-Chieh Wang, Max Welling, and Richard Zemel. Neural relational inference for interacting systems. In ICML, 2018.

[B145] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. arXiv:1609.02907, 2016a.

[B146] Thomas N Kipf and Max Welling. Variational graph auto-encoders. arXiv:1611.07308, 2016b.

[B147] Dmitry B Kireev. Chemnet: a novel neural network based method for graph/property mapping. J. Chemical Information and Computer Sciences, 35(2):175–180, 1995.

[B148] Johannes Klicpera, Janek Groß, and Stephan Günnemann. Directional message passing for molecular graphs. arXiv:2003.03123, 2020.

[B149] Iasonas Kokkinos, Michael M Bronstein, Roee Litman, and Alex M Bronstein. Intrinsic shape context descriptors for deformable shapes. In CVPR, 2012.

[B150] Patrick T Komiske, Eric M Metodiev, and Jesse Thaler. Energy flow networks: deep sets for particle jets. Journal of High Energy Physics, 2019(1):121, 2019.

[B151] Ilya Kostrikov, Zhongshi Jiang, Daniele Panozzo, Denis Zorin, and Joan Bruna. Surface networks. In CVPR, 2018.

[B152] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In NIPS, 2012.

[B153] Sofia Ira Ktena, Sarah Parisot, Enzo Ferrante, Martin Rajchl, Matthew Lee, Ben Glocker, and Daniel Rueckert. Distance metric learning using graph convolutional networks: Application to functional brain networks. In MICCAI, 2017.

[B154] Dominik Kulon, Riza Alp Guler, Iasonas Kokkinos, Michael M Bronstein, and Stefanos Zafeiriou. Weakly-supervised mesh-convolutional hand reconstruction in the wild. In CVPR, 2020.

[B155] Karol Kurach, Marcin Andrychowicz, and Ilya Sutskever. Neural random-access machines. arXiv:1511.06392, 2015.

[B156] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. Proc. IEEE, 86(11):2278–2324, 1998.

[B157] Reiner Lenz. Group theoretical methods in image processing. Springer, 1990.

[B158] Moshe Leshno, Vladimir Ya Lin, Allan Pinkus, and Shimon Schocken. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. Neural Networks, 6(6):861–867, 1993.

[B159] Ron Levie, Federico Monti, Xavier Bresson, and Michael M Bronstein. Cayleynets: Graph convolutional neural networks with complex rational spectral filters. IEEE Trans. Signal Processing, 67(1):97–109, 2018.

[B160] Ron Levie, Elvin Isufi, and Gitta Kutyniok. On the transferability of spectral graph filters. In Sampling Theory and Applications, 2019.

[B161] Bruno Lévy. Laplace-Beltrami eigenfunctions towards an algorithm that "understands" geometry. In Proc. Shape Modeling and Applications, 2006.

[B162] Yujia Li, Daniel Tarlow, Marc Brockschmidt, and Richard Zemel. Gated graph sequence neural networks. arXiv:1511.05493, 2015.

[B163] Or Litany, Alex Bronstein, Michael Bronstein, and Ameesh Makadia. Deformable shape completion with graph convolutional autoencoders. In CVPR, 2018.

[B164] Roee Litman and Alexander M Bronstein. Learning spectral descriptors for deformable shape correspondence. Trans. PAMI, 36(1):171–180, 2013.

[B165] Hsueh-Ti Derek Liu, Alec Jacobson, and Keenan Crane. A Dirac operator for extrinsic shape analysis. Computer Graphics Forum, 36(5):139–149, 2017.

[B166] Siwei Lyu and Eero P Simoncelli. Nonlinear image representation using divisive normalization. In CVPR, 2008.

[B167] Richard H MacNeal. The solution of partial differential equations by means of electrical networks. PhD thesis, California Institute of Technology, 1949.

[B168] Andreas Madsen and Alexander Rosenberg Johansen. Neural arithmetic units. arXiv:2001.05016, 2020.

[B169] Soha Sadat Mahdi, Nele Nauwelaers, Philip Joris, Giorgos Bouritsas, Shunwang Gong, Sergiy Bokhnyak, Susan Walsh, Mark Shriver, Michael Bronstein, and Peter Claes. 3d facial matching by spiral convolutional metric learning and a biometric fusion-net of demographic properties. arXiv:2009.04746, 2020.

[B170] VE Maiorov. On best approximation by ridge functions. Journal of Approximation Theory, 99(1):68–94, 1999.

[B171] Ameesh Makadia, Christopher Geyer, and Kostas Daniilidis. Correspondence-free structure from motion. IJCV, 75(3):311–327, 2007.

[B172] Stéphane Mallat. A wavelet tour of signal processing. Elsevier, 1999.

[B173] Stéphane Mallat. Group invariant scattering. Communications on Pure and Applied Mathematics, 65(10):1331–1398, 2012.

[B174] Brandon Malone, Alberto Garcia-Duran, and Mathias Niepert. Learning representations of missing data for predicting patient outcomes. arXiv:1811.04752, 2018.

[B175] Haggai Maron, Heli Ben-Hamu, Nadav Shamir, and Yaron Lipman. Invariant and equivariant graph networks. arXiv:1812.09902, 2018.

[B176] Haggai Maron, Heli Ben-Hamu, Hadar Serviansky, and Yaron Lipman. Provably powerful graph networks. arXiv:1905.11136, 2019.

[B177] Jean-Pierre Marquis. Category theory and klein's erlangen program. In From a Geometrical Point of View, pages 9–40. Springer, 2009.

[B178] Jonathan Masci, Davide Boscaini, Michael Bronstein, and Pierre Vandergheynst. Geodesic convolutional neural networks on Riemannian manifolds. In CVPR Workshops, 2015.

[B179] James Clerk Maxwell. A dynamical theory of the electromagnetic field. Philosophical Transactions of the Royal Society of London, (155):459–512, 1865.

[B180] Jason D McEwen, Christopher GR Wallis, and Augustine N Mavor-Parker. Scattering networks on the sphere for scalable and rotationally equivariant spherical cnns. arXiv:2102.02828, 2021.

[B181] Song Mei, Theodor Misiakiewicz, and Andrea Montanari. Learning with invariances in random features and kernel models. arXiv:2102.13219, 2021.

[B182] Simone Melzi, Riccardo Spezialetti, Federico Tombari, Michael M Bronstein, Luigi Di Stefano, and Emanuele Rodolà. Gframes: Gradient-based local reference frame for 3d shape matching. In CVPR, 2019.

[B183] Facundo Mémoli and Guillermo Sapiro. A theoretical and computational framework for isometry invariant recognition of point cloud data. Foundations of Computational Mathematics, 5(3):313–347, 2005.

[B184] Christian Merkwirth and Thomas Lengauer. Automatic generation of complementary descriptors with molecular graph networks. J. Chemical Information and Modeling, 45(5):1159–1168, 2005.

[B185] Mark Meyer, Mathieu Desbrun, Peter Schröder, and Alan H Barr. Discrete differential-geometry operators for triangulated 2-manifolds. In Visualization and Mathematics III, pages 35–57. 2003.

[B186] Alessio Micheli. Neural network for graphs: A contextual constructive approach. IEEE Trans. Neural Networks, 20(3):498–511, 2009.

[B187] Karla L Miller, Fidel Alfaro-Almagro, Neal K Bangerter, David L Thomas, Essa Yacoub, Junqian Xu, Andreas J Bartsch, Saad Jbabdi, Stamatios N Sotiropoulos, Jesper LR Andersson, et al. Multimodal population brain imaging in the uk biobank prospective epidemiological study. Nature Neuroscience, 19(11):1523–1536, 2016.

[B188] Marvin Minsky and Seymour A Papert. Perceptrons: An introduction to computational geometry. MIT Press, 2017.

[B189] Jovana Mitrovic, Brian McWilliams, Jacob Walker, Lars Buesing, and Charles Blundell. Representation learning via invariant causal mechanisms. arXiv:2010.07922, 2020.

[B190] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. Nature, 518(7540):529–533, 2015.

[B191] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In ICML, 2016.

[B192] Federico Monti, Davide Boscaini, Jonathan Masci, Emanuele Rodola, Jan Svoboda, and Michael M Bronstein. Geometric deep learning on graphs and manifolds using mixture model cnns. In CVPR, 2017.

[B193] Federico Monti, Fabrizio Frasca, Davide Eynard, Damon Mannion, and Michael M Bronstein. Fake news detection on social media using geometric deep learning. arXiv:1902.06673, 2019.

[B194] Christopher Morris, Kristian Kersting, and Petra Mutzel. Glocalized Weisfeiler-Lehman graph kernels: Global-local feature maps of graphs. In ICDM, 2017.

[B195] Christopher Morris, Martin Ritzert, Matthias Fey, William L Hamilton, Jan Eric Lenssen, Gaurav Rattan, and Martin Grohe. Weisfeiler and leman go neural: Higher-order graph neural networks. In AAAI, 2019.

[B196] Christopher Morris, Gaurav Rattan, and Petra Mutzel. Weisfeiler and Leman go sparse: Towards scalable higher-order graph embeddings. In NeurIPS, 2020.

[B197] Michael C Mozer. A focused back-propagation algorithm for temporal pattern recognition. Complex Systems, 3(4):349–381, 1989.

[B198] Kevin Murphy, Yair Weiss, and Michael I Jordan. Loopy belief propagation for approximate inference: An empirical study. arXiv:1301.6725, 2013.

[B199] Ryan Murphy, Balasubramaniam Srinivasan, Vinayak Rao, and Bruno Ribeiro. Relational pooling for graph representations. In ICML, 2019.

[B200] Ryan L Murphy, Balasubramaniam Srinivasan, Vinayak Rao, and Bruno Ribeiro. Janossy pooling: Learning deep permutation-invariant functions for variable-size inputs. arXiv:1811.01900, 2018.

[B201] Vinod Nair and Geoffrey E Hinton. Rectified linear units improve restricted boltzmann machines. In ICML, 2010.

[B202] John Nash. The imbedding problem for Riemannian manifolds. Annals of Mathematics, 63(1):20—63, 1956.

[B203] Behnam Neyshabur, Ryota Tomioka, and Nathan Srebro. Norm-based capacity control in neural networks. In COLT, 2015.

[B204] Emmy Noether. Invariante variationsprobleme. In König Gesellsch. d. Wiss. zu Göttingen, Math-Phys. Klassc, pages 235–257. 1918.

[B205] Maks Ovsjanikov, Jian Sun, and Leonidas Guibas. Global intrinsic symmetries of shapes. Computer Graphics Forum, 27(5):1341–1348, 2008.

[B206] Maks Ovsjanikov, Mirela Ben-Chen, Justin Solomon, Adrian Butscher, and Leonidas Guibas. Functional maps: a flexible representation of maps between shapes. ACM Trans. Graphics, 31(4):1–11, 2012.

[B207] Aditya Pal, Chantat Eksombatchai, Yitong Zhou, Bo Zhao, Charles Rosenberg, and Jure Leskovec. Pinnersage: Multi-modal user embedding framework for recommendations at pinterest. In KDD, 2020.

[B208] Sarah Parisot, Sofia Ira Ktena, Enzo Ferrante, Matthew Lee, Ricardo Guerrero, Ben Glocker, and Daniel Rueckert. Disease prediction using graph convolutional networks: application to autism spectrum disorder and alzheimer's disease. Medical Image Analysis, 48:117–130, 2018.

[B209] Razvan Pascanu, Tomas Mikolov, and Yoshua Bengio. On the difficulty of training recurrent neural networks. In ICML, 2013.

[B210] Giuseppe Patanè. Fourier-based and rational graph filters for spectral processing. arXiv:2011.04055, 2020.

[B211] Judea Pearl. Probabilistic reasoning in intelligent systems: networks of plausible inference. Elsevier, 2014.

[B212] Roger Penrose. The road to reality: A complete guide to the laws of the universe. Random House, 2005.

[B213] Bryan Perozzi, Rami Al-Rfou, and Steven Skiena. Deepwalk: Online learning of social representations. In KDD, 2014.

[B214] Tobias Pfaff, Meire Fortunato, Alvaro Sanchez-Gonzalez, and Peter W Battaglia. Learning mesh-based simulation with graph networks. arXiv:2010.03409, 2020.

[B215] Fernando J Pineda. Generalization of back propagation to recurrent and higher order neural networks. In NIPS, 1988.

[B216] Ulrich Pinkall and Konrad Polthier. Computing discrete minimal surfaces and their conjugates. Experimental Mathematics, 2(1):15–36, 1993.

[B217] Allan Pinkus. Approximation theory of the mlp model in neural networks. Acta Numerica, 8:143–195, 1999.

[B218] Tom J Pollard, Alistair EW Johnson, Jesse D Raffa, Leo A Celi, Roger G Mark, and Omar Badawi. The eicu collaborative research database, a freely available multi-center database for critical care research. Scientific Data, 5 (1):1–13, 2018.

[B219] Javier Portilla and Eero P Simoncelli. A parametric texture model based on joint statistics of complex wavelet coefficients. International journal of computer vision, 40(1):49–70, 2000.

[B220] Charles R Qi, Hao Su, Kaichun Mo, and Leonidas J Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. In CVPR, 2017.

[B221] Jiezhong Qiu, Yuxiao Dong, Hao Ma, Jian Li, Kuansan Wang, and Jie Tang. Network embedding as matrix factorization: Unifying deepwalk, line, pte, and node2vec. In WSDM, 2018.

[B222] H Qu and L Gouskos. Particlenet: jet tagging via particle clouds. arXiv:1902.08570, 2019.

[B223] Meng Qu, Yoshua Bengio, and Jian Tang. GMNN: Graph Markov neural networks. In ICML, 2019.

[B224] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training. 2018.

[B225] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. OpenAI blog, 1(8):9, 2019.

[B226] Anurag Ranjan, Timo Bolkart, Soubhik Sanyal, and Michael J Black. Generating 3D faces using convolutional mesh autoencoders. In ECCV, 2018.

[B227] Dan Raviv, Alexander M Bronstein, Michael M Bronstein, and Ron Kimmel. Symmetries of non-rigid shapes. In ICCV, 2007.

[B228] Noam Razin and Nadav Cohen. Implicit regularization in deep learning may not be explainable by norms. arXiv:2005.06398, 2020.

[B229] Scott Reed and Nando De Freitas. Neural programmer-interpreters. arXiv:1511.06279, 2015.

[B230] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. arXiv:1506.01497, 2015.

[B231] Danilo Rezende and Shakir Mohamed. Variational inference with normalizing flows. In ICML, 2015.

[B232] Maximilian Riesenhuber and Tomaso Poggio. Hierarchical models of object recognition in cortex. Nature neuroscience, 2(11):1019–1025, 1999.

[B233] AJ Robinson and Frank Fallside. The utility driven dynamic error propagation network. University of Cambridge, 1987.

[B234] Emma Rocheteau, Pietro Liò, and Stephanie Hyland. Temporal pointwise convolutional networks for length of stay prediction in the intensive care unit. arXiv:2007.09483, 2020.

[B235] Emma Rocheteau, Catherine Tong, Petar Veličković, Nicholas Lane, and Pietro Liò. Predicting patient outcomes with graph representation learning. arXiv:2101.03940, 2021.

[B236] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In MICCAI, 2015.

[B237] Frank Rosenblatt. The perceptron: a probabilistic model for information storage and organization in the brain. Psychological Review, 65(6):386, 1958.

[B238] Emanuele Rossi, Ben Chamberlain, Fabrizio Frasca, Davide Eynard, Federico Monti, and Michael Bronstein. Temporal graph networks for deep learning on dynamic graphs. arXiv:2006.10637, 2020.

[B239] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. IJCV, 115 (3):211–252, 2015.

[B240] Raif M Rustamov, Maks Ovsjanikov, Omri Azencot, Mirela Ben-Chen, Frédéric Chazal, and Leonidas Guibas. Map-based exploration of intrinsic shape differences and variability. ACM Trans. Graphics, 32(4):1–12, 2013.

[B241] Tim Salimans and Diederik P Kingma. Weight normalization: A simple reparameterization to accelerate training of deep neural networks. arXiv:1602.07868, 2016.

[B242] Alvaro Sanchez-Gonzalez, Victor Bapst, Kyle Cranmer, and Peter Battaglia. Hamiltonian graph networks with ODE integrators. arXiv:1909.12790, 2019.

[B243] Alvaro Sanchez-Gonzalez, Jonathan Godwin, Tobias Pfaff, Rex Ying, Jure Leskovec, and Peter Battaglia. Learning to simulate complex physics with graph networks. In ICML, 2020.

[B244] Aliaksei Sandryhaila and José MF Moura. Discrete signal processing on graphs. IEEE Trans. Signal Processing, 61(7):1644–1656, 2013.

[B245] Adam Santoro, David Raposo, David G Barrett, Mateusz Malinowski, Razvan Pascanu, Peter Battaglia, and Timothy Lillicrap. A simple neural network module for relational reasoning. In NIPS, 2017.

[B246] Adam Santoro, Ryan Faulkner, David Raposo, Jack Rae, Mike Chrzanowski, Theophane Weber, Daan Wierstra, Oriol Vinyals, Razvan Pascanu, and Timothy Lillicrap. Relational recurrent neural networks. arXiv:1806.01822, 2018.

[B247] Shibani Santurkar, Dimitris Tsipras, Andrew Ilyas, and Aleksander Madry. How does batch normalization help optimization? arXiv:1805.11604, 2018.

[B248] Ryoma Sato, Makoto Yamada, and Hisashi Kashima. Random features strengthen graph neural networks. arXiv:2002.03155, 2020.

[B249] Victor Garcia Satorras, Emiel Hoogeboom, and Max Welling. E(n) equivariant graph neural networks. arXiv:2102.09844, 2021.

[B250] Anna MM Scaife and Fiona Porter. Fanaroff-Riley classification of radio galaxies using group-equivariant convolutional neural networks. Monthly Notices of the Royal Astronomical Society, 2021.

[B251] Franco Scarselli, Marco Gori, Ah Chung Tsoi, Markus Hagenbuchner, and Gabriele Monfardini. The graph neural network model. IEEE Trans. Neural Networks, 20(1):61–80, 2008.

[B252] Julian Schrittwieser, Ioannis Antonoglou, Thomas Hubert, Karen Simonyan, Laurent Sifre, Simon Schmitt, Arthur Guez, Edward Lockhart, Demis Hassabis, Thore Graepel, et al. Mastering atari, go, chess and shogi by planning with a learned model. Nature, 588(7839):604–609, 2020.

[B253] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. arXiv:1707.06347, 2017.

[B254] Kristof T Schütt, Huziel E Sauceda, P-J Kindermans, Alexandre Tkatchenko, and K-R Müller. Schnet–a deep learning architecture for molecules and materials. The Journal of Chemical Physics, 148(24):241722, 2018.

[B255] Terrence J Sejnowski, Paul K Kienker, and Geoffrey E Hinton. Learning symmetry groups with hidden units: Beyond the perceptron. Physica D: Nonlinear Phenomena, 22(1-3):260–275, 1986.

[B256] Andrew W Senior, Richard Evans, John Jumper, James Kirkpatrick, Laurent Sifre, Tim Green, Chongli Qin, Augustin Žídek, Alexander WR Nelson, Alex Bridgland, et al. Improved protein structure prediction using potentials from deep learning. Nature, 577(7792):706–710, 2020.

[B257] Thomas Serre, Aude Oliva, and Tomaso Poggio. A feedforward architecture accounts for rapid categorization. Proceedings of the national academy of sciences, 104(15):6424–6429, 2007.

[B258] Ohad Shamir and Gal Vardi. Implicit regularization in relu networks with the square loss. arXiv:2012.05156, 2020.

[B259] John Shawe-Taylor. Building symmetries into feedforward networks. In ICANN, 1989.

[B260] John Shawe-Taylor. Symmetries and discriminability in feedforward network architectures. IEEE Trans. Neural Networks, 4(5):816–826, 1993.

[B261] Nino Shervashidze, Pascal Schweitzer, Erik Jan Van Leeuwen, Kurt Mehlhorn, and Karsten M Borgwardt. Weisfeiler-lehman graph kernels. JMLR, 12(9), 2011.

[B262] Jonathan Shlomi, Peter Battaglia, and Jean-Roch Vlimant. Graph neural networks in particle physics. Machine Learning: Science and Technology, 2 (2):021001, 2020.

[B263] David I Shuman, Sunil K Narang, Pascal Frossard, Antonio Ortega, and Pierre Vandergheynst. The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains. IEEE Signal Processing Magazine, 30(3):83–98, 2013.

[B264] Hava T Siegelmann and Eduardo D Sontag. On the computational power of neural nets. Journal of Computer and System Sciences, 50(1):132–150, 1995.

[B265] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. Nature, 529(7587):484–489, 2016.

[B266] David Silver, Julian Schrittwieser, Karen Simonyan, Ioannis Antonoglou, Aja Huang, Arthur Guez, Thomas Hubert, Lucas Baker, Matthew Lai, Adrian Bolton, et al. Mastering the game of go without human knowledge. Nature, 550(7676):354–359, 2017.

[B267] Eero P Simoncelli and William T Freeman. The steerable pyramid: A flexible architecture for multi-scale derivative computation. In Proceedings., International Conference on Image Processing, volume 3, pages 444–447. IEEE, 1995.

[B268] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. arXiv:1409.1556, 2014.

[B269] Alex Smola, Arthur Gretton, Le Song, and Bernhard Schölkopf. A Hilbert space embedding for distributions. In ALT, 2007.

[B270] Stefan Spalević, Petar Veličković, Jovana Kovačević, and Mladen Nikolić. Hierachial protein function prediction with tail-GNNs. arXiv:2007.12804, 2020.

[B271] Alessandro Sperduti. Encoding labeled graphs by labeling RAAM. In NIPS, 1994.

[B272] Alessandro Sperduti and Antonina Starita. Supervised neural networks for the classification of structures. IEEE Trans. Neural Networks, 8(3):714–735, 1997.

[B273] Jost Tobias Springenberg, Alexey Dosovitskiy, Thomas Brox, and Martin Riedmiller. Striving for simplicity: The all convolutional net. arXiv:1412.6806, 2014.

[B274] Balasubramaniam Srinivasan and Bruno Ribeiro. On the equivalence between positional node embeddings and structural graph representations. arXiv:1910.00452, 2019.

[B275] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. JMLR, 15(1):1929–1958, 2014.

[B276] Rupesh Kumar Srivastava, Klaus Greff, and Jürgen Schmidhuber. Highway networks. arXiv:1505.00387, 2015.

[B277] Kimberly Stachenfeld, Jonathan Godwin, and Peter Battaglia. Graph networks with spectral message passing. arXiv:2101.00079, 2020.

[B278] Jonathan M Stokes, Kevin Yang, Kyle Swanson, Wengong Jin, Andres Cubillos-Ruiz, Nina M Donghia, Craig R MacNair, Shawn French, Lindsey A Carfrae, Zohar Bloom-Ackerman, et al. A deep learning approach to antibiotic discovery. Cell, 180(4):688–702, 2020.

[B279] Heiko Strathmann, Mohammadamin Barekatain, Charles Blundell, and Petar Veličković. Persistent message passing. arXiv:2103.01043, 2021.

[B280] Norbert Straumann. Early history of gauge theories and weak interactions. hep-ph/9609230, 1996.

[B281] Jian Sun, Maks Ovsjanikov, and Leonidas Guibas. A concise and provably informative multi-scale signature based on heat diffusion. Computer Graphics Forum, 28(5):1383–1392, 2009.

[B282] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. arXiv:1409.3215, 2014.

[B283] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In CVPR, 2015.

[B284] Corentin Tallec and Yann Ollivier. Can recurrent neural networks warp time? arXiv:1804.11188, 2018.

[B285] Hao Tang, Zhiao Huang, Jiayuan Gu, Bao-Liang Lu, and Hao Su. Towards scale-invariant graph-related problem solving by iterative homogeneous gnns. In NeurIPS, 2020.

[B286] Jian Tang, Meng Qu, Mingzhe Wang, Ming Zhang, Jun Yan, and Qiaozhu Mei. Line: Large-scale information network embedding. In WWW, 2015.

[B287] Gabriel Taubin, Tong Zhang, and Gene Golub. Optimal surface smoothing as filter design. In ECCV, 1996.

[B288] Shantanu Thakoor, Corentin Tallec, Mohammad Gheshlaghi Azar, Rémi Munos, Petar Veličković, and Michal Valko. Bootstrapped representation learning on graphs. arXiv:2102.06514, 2021.

[B289] Nathaniel Thomas, Tess Smidt, Steven Kearnes, Lusann Yang, Li Li, Kai Kohlhoff, and Patrick Riley. Tensor field networks: Rotation- and translation-equivariant neural networks for 3D point clouds. arXiv:1802.08219, 2018.

[B290] Renate Tobies. Felix Klein—-mathematician, academic organizer, educational reformer. In The Legacy of Felix Klein, pages 5–21. Springer, 2019.

[B291] Andrew Trask, Felix Hill, Scott Reed, Jack Rae, Chris Dyer, and Phil Blunsom. Neural arithmetic logic units. arXiv:1808.00508, 2018.

[B292] John Tromp and Gunnar Farnebäck. Combinatorics of go. In International Conference on Computers and Games, 2006.

[B293] Alexandre B Tsybakov. Introduction to nonparametric estimation. Springer, 2008.

[B294] Dmitry Ulyanov, Andrea Vedaldi, and Victor Lempitsky. Instance normalization: The missing ingredient for fast stylization. arXiv:1607.08022, 2016.

[B295] Aaron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, and Koray Kavukcuoglu. Wavenet: A generative model for raw audio. arXiv:1609.03499, 2016a.

[B296] Aaron van den Oord, Nal Kalchbrenner, and Koray Kavukcuoglu. Pixel recurrent neural networks. In ICML, 2016b.

[B297] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In NIPS, 2017.

[B298] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph Attention Networks. ICLR, 2018.

[B299] Petar Veličković, Rex Ying, Matilde Padovano, Raia Hadsell, and Charles Blundell. Neural execution of graph algorithms. arXiv:1910.10593, 2019.

[B300] Petar Veličković, Lars Buesing, Matthew C Overlan, Razvan Pascanu, Oriol Vinyals, and Charles Blundell. Pointer graph networks. arXiv:2006.06380, 2020.

[B301] Petar Veličković, Wiliam Fedus, William L. Hamilton, Pietro Liò, Yoshua Bengio, and R Devon Hjelm. Deep Graph Infomax. In ICLR, 2019.

[B302] Kirill Veselkov, Guadalupe Gonzalez, Shahad Aljifri, Dieter Galea, Reza Mirnezami, Jozef Youssef, Michael Bronstein, and Ivan Laponogov. Hyperfoods: Machine intelligent mapping of cancer-beating molecules in foods. Scientific Reports, 9(1):1–12, 2019.

[B303] Oriol Vinyals, Meire Fortunato, and Navdeep Jaitly. Pointer networks. arXiv:1506.03134, 2015.

[B304] Oriol Vinyals, Samy Bengio, and Manjunath Kudlur. Order matters: Sequence to sequence for sets. In ICLR, 2016.

[B305] Ulrike von Luxburg and Olivier Bousquet. Distance-based classification with lipschitz functions. JMLR, 5:669–695, 2004.

[B306] Martin J Wainwright and Michael Irwin Jordan. Graphical models, exponential families, and variational inference. Now Publishers Inc, 2008.

[B307] Yu Wang and Justin Solomon. Intrinsic and extrinsic operators for shape analysis. In Handbook of Numerical Analysis, volume 20, pages 41–115. Elsevier, 2019.

[B308] Yu Wang, Mirela Ben-Chen, Iosif Polterovich, and Justin Solomon. Steklov spectral geometry for extrinsic shape analysis. ACM Trans. Graphics, 38(1): 1–21, 2018.

[B309] Yu Wang, Vladimir Kim, Michael Bronstein, and Justin Solomon. Learning geometric operators on meshes. In ICLR Workshops, 2019a.

[B310] Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E Sarma, Michael M Bronstein, and Justin M Solomon. Dynamic graph CNN for learning on point clouds. ACM Trans. Graphics, 38(5):1–12, 2019b.

[B311] Max Wardetzky. Convergence of the cotangent formula: An overview. Discrete Differential Geometry, pages 275–286, 2008.

[B312] Max Wardetzky, Saurabh Mathur, Felix Kälberer, and Eitan Grinspun. Discrete Laplace operators: no free lunch. In Symposium on Geometry Processing, 2007.

[B313] Maurice Weiler, Mario Geiger, Max Welling, Wouter Boomsma, and Taco Cohen. 3d steerable cnns: Learning rotationally equivariant features in volumetric data. arXiv:1807.02547, 2018.

[B314] Boris Weisfeiler and Andrei Leman. The reduction of a graph to canonical form and the algebra which appears therein. NTI Series, 2(9):12–16, 1968.

[B315] Paul J Werbos. Generalization of backpropagation with application to a recurrent gas market model. Neural Networks, 1(4):339–356, 1988.

[B316] Hermann Weyl. Elektron und gravitation. i. Zeitschrift für Physik, 56(5-6): 330–352, 1929.

[B317] Hermann Weyl. Symmetry. Princeton University Press, 2015.

[B318] Marysia Winkels and Taco S Cohen. Pulmonary nodule detection in ct scans with equivariant cnns. Medical Image Analysis, 55:15–26, 2019.

[B319] Jeffrey Wood and John Shawe-Taylor. Representation theory and invariant neural networks. Discrete Applied Mathematics, 69(1-2):33–60, 1996.

[B320] Felix Wu, Amauri Souza, Tianyi Zhang, Christopher Fifty, Tao Yu, and Kilian Weinberger. Simplifying graph convolutional networks. In ICML, 2019.

[B321] Yuxin Wu and Kaiming He. Group normalization. In ECCV, 2018.

[B322] Da Xu, Chuanwei Ruan, Evren Korpeoglu, Sushant Kumar, and Kannan Achan. Inductive representation learning on temporal graphs. arXiv:2002.07962, 2020a.

[B323] Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. How powerful are graph neural networks? arXiv:1810.00826, 2018.

[B324] Keyulu Xu, Jingling Li, Mozhi Zhang, Simon S Du, Ken-ichi Kawarabayashi, and Stefanie Jegelka. What can neural networks reason about? arXiv:1905.13211, 2019.

[B325] Keyulu Xu, Jingling Li, Mozhi Zhang, Simon S Du, Ken-ichi Kawarabayashi, and Stefanie Jegelka. How neural networks extrapolate: From feedforward to graph neural networks. arXiv:2009.11848, 2020b.

[B326] Yujun Yan, Kevin Swersky, Danai Koutra, Parthasarathy Ranganathan, and Milad Heshemi. Neural execution engines: Learning to execute subroutines. arXiv:2006.08084, 2020.

[B327] Chen-Ning Yang and Robert L Mills. Conservation of isotopic spin and isotopic gauge invariance. Physical Review, 96(1):191, 1954.

[B328] Zhilin Yang, William Cohen, and Ruslan Salakhudinov. Revisiting semi-supervised learning with graph embeddings. In ICML, 2016.

[B329] Jonathan S Yedidia, William T Freeman, and Yair Weiss. Bethe free energy, kikuchi approximations, and belief propagation algorithms. NIPS, 2001.

[B330] Rex Ying, Ruining He, Kaifeng Chen, Pong Eksombatchai, William L Hamilton, and Jure Leskovec. Graph convolutional neural networks for web-scale recommender systems. In KDD, 2018.

[B331] Jiaxuan You, Rex Ying, and Jure Leskovec. Position-aware graph neural networks. In ICML, 2019.

[B332] Manzil Zaheer, Satwik Kottur, Siamak Ravanbakhsh, Barnabas Poczos, Russ R Salakhutdinov, and Alexander J Smola. Deep sets. In NIPS, 2017.

[B333] Wojciech Zaremba and Ilya Sutskever. Learning to execute. arXiv:1410.4615, 2014.

[B334] Wei Zeng, Ren Guo, Feng Luo, and Xianfeng Gu. Discrete heat kernel determines discrete riemannian metric. Graphical Models, 74(4):121–129, 2012.

[B335] Jiani Zhang, Xingjian Shi, Junyuan Xie, Hao Ma, Irwin King, and Dit-Yan Yeung. Gaan: Gated attention networks for learning on large and spatiotemporal graphs. arXiv:1803.07294, 2018.

[B336] Yuyu Zhang, Xinshi Chen, Yuan Yang, Arun Ramamurthy, Bo Li, Yuan Qi, and Le Song. Efficient probabilistic logic reasoning with graph neural networks. arXiv:2001.11850, 2020.

[B337] Rong Zhu, Kun Zhao, Hongxia Yang, Wei Lin, Chang Zhou, Baole Ai, Yong Li, and Jingren Zhou. Aligraph: A comprehensive graph neural network platform. arXiv:1902.08730, 2019.

[B338] Weicheng Zhu and Narges Razavian. Variationally regularized graph-based representation learning for electronic health records. arXiv:1912.03761, 2019.

[B339] Yanqiao Zhu, Yichen Xu, Feng Yu, Qiang Liu, Shu Wu, and Liang Wang. Deep graph contrastive representation learning. arXiv:2006.04131, 2020.

[B340] Marinka Zitnik, Monica Agrawal, and Jure Leskovec. Modeling polypharmacy side effects with graph convolutional networks. Bioinformatics, 34 (13):i457–i466, 2018.