深度学习的物理学

Physics of Deep Learning

Aleksander Czejdo　Tudor Dimofte
Brianna Grado-White　Charles Renshaw-Whitman

本地交付候选：逐节独立审校修订版

Iliad Intensive 讲义 · 2026-10-27
Model: 初译模型未核实；本轮审校 gpt-6.1-sol（high）
审核：曹溪能
Updated: 2026-11-04

简介

本讲义介绍受物理学启发的深度学习分析与研究，尤其关注统计力学、统计场论以及少量动力系统方法。

译本说明

本译稿依据首页日期为 2026-10-27 的 Iliad Intensive 讲义 *Physics of Deep Learning*，作者为 Aleksander Czejdo、Tudor Dimofte、Brianna Grado-White 与 Charles Renshaw-Whitman。原文可从 `https://iliad-intensive.org/downloads/qft/qft-nosol.pdf` 取得；配套幻灯片为 `https://iliad-intensive.org/downloads/qft/qft-slides.pdf`。本轮核验的站点文件与冻结输入逐字节一致。官方仓库的许可为 CC BY 4.0，许可证据随源码保留。本译稿进行了中文翻译、重新排版和独立审校；译者补充均以译注明示，源文疑点保留原式并另记。当前原文为不含习题答案的 nosol 版，附录 C 没有实际解答。图中文字保留原图并配中文对照；第三方素材的权利与最终公开发布仍须单独核实。封面审核字段遵循项目格式，本地候选尚待主控验收。

目录

—1 预备知识 **4**

0 一天的教学安排 **4**

0.1 日程 5

0.2 主要参考文献 5

1 导读：学习力学 **5**

2 学习的统计力学 **6**

2.1 贝叶斯学习模型 7

2.2 为何损失的指数是似然 8

2.3 配分函数、自由能与累积量 9

2.4 物理学实例：伊辛模型 11

2.5 相与相变 13

2.6 伊辛感知机：学习中的一级相变 17

2.7 与量子场论的比较 19

3 初始化时的大宽度：高斯过程极限 **19**

3.1 记号 20

3.2 网络归一化 20

3.3 高斯过程 21

3.4 NNGP 对应关系 24

3.5 用泛函积分分析 NNGP 25

3.6 L/N 27

3.7 混沌边缘 28

4 训练期间的神经切线核与大宽度 29
4.1 梯度流与 NTK 30
4.1.1 梯度流的几何 30
4.2 特征 32
4.3 大宽度下的常数 NTK 32
4.4 惰性学习 35
4.5 小结 36
4.6 大宽度下的贝叶斯学习：核学习 37

5 平均场标度 38
5.1 物理学中的平均场理论 39
5.1.1 热身：Curie–Weiss 磁体 39
5.1.2 平均场模型的一般形式 40
5.2 单隐藏层网络的平均场标度 40
5.2.1 初始化 41
5.2.2 损失是平均场能量 41
5.2.3 运动方程与平均场 41
5.2.4 从粒子到测度：连续性方程 42
5.2.5 McKean–Vlasov 方程与自洽性 43
5.3 NTK 不再是常数：特征学习 45
5.4 标度旋钮与最大更新参数化 46
5.5 这个框架有什么用途? 46
5.6 作为惰性到丰富转变的顿悟：阅读习题 47
5.7 贝叶斯顿悟：一级相变（另一份阅读） 48

6 非平衡物理、MSRJD 与 DMFT 49
6.1 从随机动力学到路径积分：MSRJD 形式 50
6.2 作为动力学相变的双下降 52
6.2.1 模型定义与形式 52
6.2.2 通过训练误差与泛化误差概览结果 54
6.3 动力学平均场理论（DMFT） 55
6.3.1 自洽性 56
6.3.2 近期深度学习应用 57

7 标度律 57
7.1 经验定律 58
7.2 联合定律、瓶颈与 Chinchilla 修订 59
7.3 定律从何而来? 60
7.4 理论提案概览 61

7.5 量化模型：从技能统计得到指数 63
7.6 涌现：由错开的悬崖组成平滑定律 64
7.7 从几何与谱得到指数 65
7.7.1 几何：数据流形论证 65
7.7.2 谱：从核本征值得到标度律 65
7.8 一个可解的大 N 场论 66
7.9 同时调节所有旋钮：动力学理论 66
7.10 超越预训练：后训练与测试时标度 67

A 副本方法 **68**
A.1 退火近似错在哪里 68
A.2 副本 68
A.3 一种变体：球面感知机 70

B 从线性回归到核回归 **72**
B.1 线性回归 72
B.2 使用非线性特征的线性回归 74
B.3 核回归 75
B.4 核岭回归 78
B.5 线性化网络是核岭回归模型 80

C 习题解答 **81**

−1 预备知识

我们不要求读者具备物理背景，不过阅读建议的参考资料可能有所帮助。我们假定读者具备：

- 概率论和贝叶斯推断的基本知识；
- 对简单神经网络（多层感知机，MLP）的熟悉；
- 本科水平的微积分和线性代数；
- 在少数地方还需要微分几何知识。

你将学到什么 学完本讲义后，你应当能够：

- 运用贝叶斯学习的统计力学词典——能量、熵、配分函数、自由能、累积量、序参量和淬火平均——并解释为何损失函数的指数可以作为似然。
- 在平均场近似下求解伊辛模型；解释什么是相变，为何有限系统呈现平滑的 sigmoid 曲线和不断升高的磁化率峰，而非真正的不连续折角；说明伊辛感知机如何实现通向完美泛化的一级相变，包括亚稳态所带来的滞后。
- 推导初始化时宽神经网络的高斯过程描述，并解释输入连接数归一化、深宽比和混沌边缘的作用。
- 推导神经切线核（NTK），并解释为何它在大宽度下冻结，使得训练退化为核回归，而不发生特征学习。
- 启发式推导单隐藏层网络的平均场极限——将神经元看成相互作用的粒子，并涉及自洽性与 McKean–Vlasov 方程；解释其随动的核如何编码特征学习；将 NTK 与平均场极限放在不同标度的连续谱上，并联系最大更新参数化（μP）与超参数迁移。
- 比较对顿悟（grokking）的两种理论解释——平衡态一级相变和延迟的惰性到丰富动力学转变——并提出能区分二者的实验。
- 识别训练动力学的 MSRJD/DMFT 路径积分表述、关联函数和响应函数的作用，以及作为动力学相变的双下降现象。
- 推导量化模型的三个标度律，将“涌现”解释为错开的陡变聚合而成，并概览标度指数的来源：技能统计、数据几何和核的谱。

0 一天的教学安排

本讲义包含的内容远远超出一天能够讲授的范围。本节记录 Iliad Intensive 于 2026 年 9 月活动的第 B.6 天在一天之内教授的一组选材，作为讲义使用方式的一个实例。这一天交替安排三次讲座和练习：讲座使用与讲义配套的幻灯片，练习环节中参与者从讲义中选择一道习题，独立或分小组完成。最后进行短篇阅读和讨论。

幻灯片对应讲义同一文件夹中的 `slides.tex`。网站构建会编译该文件，并在本章网页顶部的“Slides”一行提供下载；也可以直接访问 `https://iliad-team.github.io/iliad-intensive/downloads/qft/qft-slides.pdf`。其三个部分对应下面的三次讲座：第 1–20 帧（第一部分）、第 21–41 帧（第二部分）和第 42–52 帧（第三部分）。讲座有意将推导留给练习环节，因此幻灯片按设计较为简略；讲义对应章节补充了幻灯片所述内容。

0.1 日程

时间	环节	讲义对应位置
10:00–11:00	讲座第一部分：贝叶斯学习与相变	第 2.1–2.5 节
11:00–11:15	休息	
11:15–12:00	第一部分练习（选一道）	习题 2.1–2.3
12:00–12:30	讲座第二部分 a：初始化时的大宽度；NTK	第 3.1–3.4、3.6、4.1–4.2 节
12:30–13:30	午餐	
13:30–14:00	讲座第二部分 b：训练期间的大宽度；平均场标度	第 4.3–4.4、5.2–5.4 节
14:00–15:00	第二部分练习或实验（选一道）	习题 3.3、4.4、4.5、5.3
15:00–15:45	讲座第三部分：神经标度律的理论与实践	第 7.1–7.5 节
15:45–16:15	休息	
16:15–17:00	第三部分练习	习题 7.1
17:00–17:30	阅读“学习力学”	第 1 节
17:30–17:50	分组讨论	第 1 节的问题
17:50–18:00	反馈	

0.2 主要参考文献

这一天的教学基于以下参考资料，它们也都出现在讲义的其他部分。第一部分：Tong 关于统计场论和动力学理论的讲义 [89, 88] 提供讲座背后的物理；Engel 和 Van den Broeck[26] 介绍感知机研究传统；Györgyi[35] 讨论伊辛感知机相变。第二部分：Hanin 的讲义 [37] 及 Roberts、Yaida 和 Hanin[71] 讨论大宽度极限与 L/N 展开；Ringel 等人 [69] 讨论深度学习中的统计场论；Spiliopoulos、Sowers 和 Sirignano[84] 讨论严格的 NTK 与平均场极限；Lin[54] 通过经验 NTK 实验识别特征；以及关于顿悟的两种解释 [49, 73]，它们未在讲座中讲授，但适合作为后续阅读（第 5.6 和 5.7 节）。第三部分：Kaplan 等人 [44] 和 Henighan 等人 [39] 讨论经验定律；Hoffmann 等人 [41] 和 Porian 等人 [66] 讨论 Chinchilla 及其与 Kaplan 结果的协调；Michaud 等人 [57] 讨论量化模型；Maloney、Roberts 和 Sully[55] 及 Bordelon、Atanasov 和 Pehlevan[9] 讨论可解的场论。

关于学习的物理学，还有 Renshaw-Whitman 在 2026 年 8 月 Intensive 讲授的一份互补性介绍 [68]；附录 B 改编自该介绍。

1 导读：学习力学

综述 [80] 认为，深度学习的科学理论——“学习力学”——已经开始形成，并将证据归纳为五条汇聚的线索：解析可解的情形、有启发性的极限、简单经验定律、解耦的超参数，以及普适

现象。该文主体详细展开前两条线索，并对其余三条作了部分介绍。本讲义也将采取大致相同的做法，因此值得把这五条线索作为后续内容的路线图。

论文的出发点值得细细体会，因为它为整个主题定下了基调。一个深度学习系统完全由四种明确的要素指定：架构（简单线性和非线性映射的复合）、数据集、目标函数和学习规则（从随机初始化出发，进行基于梯度的更新）。没有什么是隐藏的：每一步的每个参数、每个梯度和每个中间激活量，都可以按我们希望的精度测量。借用所读论文的说法，深度学习直接暴露了自身的运动方程——核心挑战不是不透明，而是复杂性。这使该领域与真正不透明的科学领域大不相同：在神经科学或细胞生物学中，微观运动方程未知，而且状态大部分不可测；在高能物理中，我们必须从散射振幅间接推断微观规律。更好的类比是流体动力学：在那里，我们也拥有微观规律——对于深度学习，更新方程只有五行代码——缺少的是有效描述，即 Navier–Stokes 方程的对应物。

阅读文献 [80] 的第 2 节（仅此一节），并思考下列问题：

1. 对阅读材料表 1 中的物理类比排序（可解模型与氢原子；极限与热力学极限；经验定律与开普勒及普朗克；超参数与雷诺数；普适性与临界现象）。哪些最有说服力？你认为哪些对理解深度学习最有用？

2. 离散化及其他近似。阅读材料中的“离散化假说”提出，实际网络最好被理解为无限尺度模型带噪声的有限近似——如同偏微分方程的有限差分离散化——因此有限尺度效应通常会降低性能，而非带来性能。根据你迄今所学，这种看法准确吗？该假说可以证伪：若某种有限尺度效应带来任何极限都无法实现的普遍收益，它就会被推翻。有哪些可能的实验或设定能够证伪它？

3. 对对齐问题而言什么真正重要？阅读材料希望得到可证伪、定量的平均情形预测，而非最坏情形界——即物理学式的研究，而非经典学习理论。这样会失去什么？例如，对于对齐，我们希望得到最坏情形保证，还是预测典型能力？五条证据线索中，哪条与对齐最相关？

在学习本讲义的后续内容、进一步了解深度学习中受物理启发的方法时，可以再回头思考这些问题。

2 学习的统计力学

将物理学应用于学习理论的研究积累深厚、体系成熟，其中许多工作是把统计力学应用于贝叶斯学习。经典教材是 Engel 和 Van den Broeck 的著作 [26]；现代综述包括 [98, 6]；至于相关物理学本身，一个极佳的参考资料是 David Tong 的统计场论讲义 [89]，本讲义第 2.4–2.5 节主要遵循该讲义。

本节聚焦贝叶斯学习模型。首先回顾这一模型、它为何是对网络实际训练方式的合理理想化，以及损失函数的指数为何可以称为似然（第 2.1–2.2 节）。然后转向物理：引入配分函数、自由能与累积量（第 2.3 节），并在平均场近似下研究伊辛模型，逐步引出一级和二级相变（第 2.4–2.5 节）。这些准备最终用于一个与伊辛磁体相对应的学习问题：伊辛感知机，它呈现通向完美泛化的一级相变；我们把它留作一道自成体系的引导式习题（第 2.6 节）。第 2.7 节则为具有量子场论背景的读者提供术语对应指南。这里引入的序参量、自由能、鞍点、淬火平均和相变等概念将在讲义中反复出现。

2.1 贝叶斯学习模型

考虑一个参数为 $\theta \in \mathbb{R}^P$ 的网络 f_θ，在 n 个样本 $(x^\mu, y^\mu)_{\mu=1}^n$ 上训练，以最小化损失

$$\mathcal{L}(\theta) = \sum_{\mu=1}^{n} \ell\big(f_\theta(x^\mu), y^\mu\big), \tag{2.1}$$

即单样本损失 ℓ 在样本上的求和。实际中，网络被随机初始化为 $\theta_0 \sim \pi(\theta)$，并使用某种梯度下降方法训练，大致有

$$\Delta\theta \approx -\eta\, \nabla_\theta \mathcal{L}(\theta). \tag{2.2}$$

对此过程的一种常用理想化，即本节要讨论的模型，是贝叶斯学习。它认为训练后的参数应视为从以下后验分布中抽样：

$$p_\beta(\theta) = \frac{1}{Z} e^{-\beta\mathcal{L}(\theta)} \pi(\theta), \qquad\qquad Z = \int d\theta\, e^{-\beta\mathcal{L}(\theta)} \pi(\theta). \tag{2.3}$$

这里初始化分布 $\pi(\theta)$ 起贝叶斯先验的作用，$e^{-\beta\mathcal{L}(\theta)}$ 则解释为给定参数 θ 时训练数据的似然（第 2.2 节解释为何这一解释合理）。正数 β 称为逆温度，控制数据对参数的约束强度。稍后我们会看到，它可以粗略衡量已经进行了多少训练。

β 的一种解释。 将损失写成样本平均的 n 倍很方便：

$$\mathcal{L}(\theta) = n\, L_n(\theta), \qquad\qquad L_n(\theta) := \frac{1}{n} \sum_{\mu=1}^{n} \ell\big(f_\theta(x^\mu), y^\mu\big). \tag{2.4}$$

经验损失 L_n 在 $n \to \infty$ 时保持有限，并收敛于总体损失 $L(\theta) := \mathbb{E}_{(x,y)} \ell(f_\theta(x), y)$，即关于真实数据分布的期望。因此 n 很大时，后验为

$$p_\beta(\theta) \propto e^{-n\beta L(\theta)} \pi(\theta), \tag{2.5}$$

样本数 n 总与逆温度以 $n\beta$ 的组合相伴。增加样本数等同于降低温度。此外，如果每个训练步骤都重新抽取样本，n 也可粗略衡量训练时间。总而言之：更多数据 = 更多训练 = 更大的 $n\beta$ = 更低的温度。我们经常简记为 $e^{-\beta L}$，但应记住有效的 β 随 n 增大。

贝叶斯方法与梯度下降。 我们训练网络并非从式 (2.3) 抽样，而是采用梯度下降。那么，为何贝叶斯模型是有用的理想化？两者有两种联系。

第一种是启发式的：刚才描述的 $n \to \infty$（更多样本、更长训练）与 $\beta \to \infty$（更低温度）之间的类比。正如后面将看到的，扫描 β 这样的参数可以使系统经历相变，而这个类比预示训练也可能如此。它仅仅是类比。特别地，当系统被动态驱动穿过一级相变时，相变会因滞后而推迟（第 2.5 节），因此贝叶斯模型对时间的预测应谨慎对待。训练的真正动力学形式——MSRJD 路径积分——将在第 6 节出现。

第二种联系是精确的，也使贝叶斯模型能够在实践中检验。把随机梯度下降（SGD）的批次噪声替换为恒定的各向同性高斯噪声，便得到 Langevin 动力学：

	离散优化器	连续（随机）微分方程
SGD：	$\Delta\theta = -\eta(\nabla_\theta\mathcal{L} + \text{批次噪声})$	$\dot\theta = -\eta\nabla_\theta\mathcal{L} + \frac{\eta}{\sqrt{B}}\Sigma(\theta)^{1/2} d\xi$
GD：	$\Delta\theta = -\eta\nabla_\theta\mathcal{L}$	$\dot\theta = -\eta\nabla_\theta\mathcal{L}$
LD：	$\Delta\theta = -\eta\nabla_\theta\mathcal{L} + \sqrt{2\eta T}\,\xi$	$\dot\theta = -\eta\nabla_\theta\mathcal{L} + \sqrt{2\eta T}\, d\xi$

(2.6)

这里 ξ 是均值为零、协方差为 I 的高斯噪声，η 是学习率，T 称为温度（或扩散常数）。左侧的每个离散算法都有右侧的连续时间极限，通过缩小步长并相应增加步数得到：梯度下降变为梯度流，Langevin 动力学变为 Langevin 方程，即一个随机微分方程。关键事实是，如果从任意合理的参数分布出发，按照 Langevin 方程演化（且 $\mathcal{L}$ 足够良好），则分布在长时间极限下收敛到 Gibbs 分布

$$p(\theta) = \frac{1}{Z} e^{-\beta \mathcal{L}(\theta)}, \qquad \beta = 1/T. \tag{2.7}$$

关于这一收敛的物理学讨论，参见 [88, 第 3 章]。可通过对修正后的损失 $\mathcal{L}(\theta) - \beta^{-1} \log \pi(\theta)$ 进行训练来纳入先验，从而得到式 (2.3)。因此，可通过 Langevin 训练构造贝叶斯后验，这也是通常检验从式 (2.3) 得出的理论预测的方式。注意，Langevin 路径提供了与前一种不同的贝叶斯—梯度联系：在这里，固定 T 并令训练时间 $t \to \infty$ 得到 $\beta = 1/T$ 时的后验；固定 t 并令 $T \to 0$ 则得到梯度流。

备注。 SGD 本身比 Langevin 动力学复杂。其有效噪声的协方差 $\Sigma(\theta)$ 依赖于损失景观中的位置，而且 SGD 在长时间下未必收敛到任何平稳分布。尽管贝叶斯学习与 SGD/Adam 训练之间存在许多定性和经验上的相似之处，二者的精确关系仍是开放问题。我们将反复比较两者：在第 4 节（梯度流）和第 4.6 节（贝叶斯）研究宽网络；在第 5 节 [73] 研究顿悟玩具模型；并在文献 [18] 中通过奇异学习理论的视角研究叠加的玩具模型 [25]。

2.2 为何损失的指数是似然

贝叶斯模型将 $e^{-\beta \mathcal{L}(\theta)}$ 看作给定参数时训练数据的概率。对于深度学习中实际使用的损失函数，这并非比喻：这些损失被设计为负对数似然，因此最小化损失就是最大似然估计。两个例子涵盖了大部分实际情况。

均方误差。 假设标签等于网络输出加高斯噪声，即 $y = f_\theta(x) + \epsilon$，其中 $\epsilon \sim \mathcal{N}(0, \sigma^2)$。那么给定输入与参数时，标签的概率密度为

$$p(y \mid x, \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} \big(y - f_\theta(x)\big)^2 \right], \tag{2.8}$$

对于 n 个独立样本，

$$\prod_{\mu=1}^{n} p(y^\mu \mid x^\mu, \theta) \propto e^{-\beta \mathcal{L}(\theta)}, \qquad \mathcal{L}(\theta) = \frac{1}{2} \sum_{\mu=1}^{n} \big(f_\theta(x^\mu) - y^\mu\big)^2, \qquad \beta = \frac{1}{\sigma^2}. \tag{2.9}$$

均方误差（MSE）损失是高斯噪声模型的负对数似然，逆温度是噪声方差的倒数。标签噪声越大，后验温度越高，对参数的约束就越弱。

交叉熵。 对于分类问题，网络输出 K 个类别上的概率分布 $p_\theta(y \mid x)$，通常由其 K 个输出值经 softmax 得到。交叉熵损失为 $\ell = -\log p_\theta(y \mid x)$，因此

$$\prod_{\mu=1}^{n} p_\theta(y^\mu \mid x^\mu) = e^{-\mathcal{L}(\theta)} \tag{2.10}$$

精确成立，且 $\beta = 1$：交叉熵损失的指数就是似然，不需要另选噪声模型。语言模型的下一个词元损失也同样如此，它恰是模型赋予训练语料的对数概率。[1]

一般模式。 只要损失是负对数似然，$e^{-\mathcal{L}}$ 就是似然，而式 (2.3) 在 $\beta = 1$ 时就是教科书中的贝叶斯后验。$\beta \neq 1$ 对应一个调温后验。当噪声水平未知时，它自然出现（如式 (2.9)）；它也是一个有用的理论调节参数：正如上文对 $n\beta$ 的解释所表明的，温度与样本数在贝叶斯模型中可以互换。还有一个有用的极限情形：某些损失是硬约束，当预测正确时 $\ell = 0$，错误时 $\ell = \infty$。这时 $e^{-\ell}$ 是阶跃函数，后验在能够拟合每个训练样本的参数上均匀分布，β 完全不再出现。这就是零温极限，也是第 2.6 节伊辛感知机所采用的设定。

2.3 配分函数、自由能与累积量

贝叶斯后验式 (2.3) 看起来与一个同热浴平衡的热系统——统计力学的基本对象——完全一样。对应关系为：

贝叶斯学习	统计力学
参数 $\theta \in \mathbb{R}^P$	系统的微观状态（例如 P 个电子的自旋）
损失 $\mathcal{L}(\theta)$	能量 $E(\theta)$ 或欧几里得作用量 $S(\theta)$
后验 $p(\theta) \propto e^{-\beta\mathcal{L}(\theta)}$	温度 $T = 1/\beta$ 下的 Boltzmann 分布
样本数 n 或训练时间	逆温度 β
参数个数 P	自由度个数 N

要纳入先验 $\pi(\theta)$，只需将能量重新定义为 $E(\theta) = \mathcal{L}(\theta) - \beta^{-1}\log\pi(\theta)$，于是 $e^{-\beta E} = e^{-\beta\mathcal{L}}\pi$。以下我们像物理学家一样，用 $E(\theta)$ 表示指数中相应的量，并以 N 表示自由度数；对于网络，$N = P$。

热力学极限。 统计力学研究自由度数目非常多的系统，并研究 $N \to \infty$ 时的行为，即热力学极限。在这个极限下，需要区分与 N 成正比增长的广延量（例如气体的总能量）和保持有限的强度量（如温度或单位粒子的能量）。这两种概念可以直接用于学习：对于具有 P 个参数、n 个样本的问题，损失式 (2.1) 相对于 n 是广延的，而经验损失 L_n 是强度量。本讲义中的许多近似都采取某种热力学极限，令参数数量、宽度或样本数量趋于无穷。

配分函数和自由能。 式 (2.3) 中的归一化常数

$$Z(\beta) = \int d\theta\, e^{-\beta E(\theta)} \tag{2.11}$$

称为配分函数。从贝叶斯观点看，它是数据的边缘似然。它依赖 β 以及问题中的其他超参数。其对数定义了自由能[2]和自由能密度：

$$F(\beta) := -\log Z(\beta), \qquad \varphi := \frac{F}{N}. \tag{2.12}$$

关注 F 而非 Z 有三个原因。第一，F 是广延的，φ 是强度量：当 $N \to \infty$ 时自由能密度存在极限，而 Z 本身则指数地大或小。第二，“F 被最小化”：在大 N 下，积分 (2.11) 由参数空间中局域自由能最小的区域支配，因此系统的宏观状态通过最小化 F 找到。第 2.4 节会使这一说法精确化。第三，F 的导数可以计算期望值，如下所示。

[1] 译注：原文此处写作 “log-probability”；按照本段前面采用的损失为负对数似然的约定，通常应为负对数概率。此处保留原文表述。

[2] 物理学家的自由能是 $-\beta^{-1}\log Z$；我们在全文中吸收因子 β，使 F 无量纲。

源与累积量。 假设我们关心可观测量 $O_i(\theta)$ 的期望值，其中 O_i 是参数的函数。在指数中加入源项 J^i：

$$Z(\beta, J) = \int d\theta\, e^{-\beta E(\theta) + \sum_i J^i O_i(\theta)}, \qquad F(\beta, J) = -\log Z(\beta, J). \tag{2.13}$$

在积分号下求导，得到

$$\mathbb{E}(O_i) = -\left.\frac{\partial F}{\partial J^i}\right|_{J=0}, \qquad \mathrm{Cov}(O_i, O_j) = -\left.\frac{\partial^2 F}{\partial J^i \partial J^j}\right|_{J=0}, \tag{2.14}$$

一般地，p 阶导数给出 p 阶累积量：

$$\kappa_p(O_{i_1}, \ldots, O_{i_p}) = -\left.\frac{\partial^p F}{\partial J^{i_1} \cdots \partial J^{i_p}}\right|_{J=0}. \tag{2.15}$$

这些量依次是均值、协方差、三阶中心矩，而从 $p = 4$ 起则是对高斯变量为零的矩的组合。带源自由能是累积量的生成函数。累积量将在第 3.3 节以场论的形式再次出现，用来衡量初始化时网络偏离高斯过程的程度。

如果我们唯一关心的可观测量是能量本身，就不需要源：β 已经与 E 耦合，且

$$\mathbb{E}(E) = \frac{\partial F}{\partial \beta}, \qquad \mathrm{Var}(E) = -\frac{\partial^2 F}{\partial \beta^2}, \qquad \kappa_3(E) = \frac{\partial^3 F}{\partial \beta^3}, \quad \ldots \tag{2.16}$$

我们很快会再次遇到这些导数：相变正是由它们的不连续性定义的。[3]

习题 2.1（配分函数、源与累积量）。 （$\star$）考虑 Boltzmann 分布 $p_\beta(\theta) \propto e^{-\beta E(\theta)}$、可观测量 $O(\theta)$，以及带源配分函数 $Z(\beta, J) = \int d\theta\, e^{-\beta E(\theta) + JO(\theta)}$，其中 $F = -\log Z$。所有期望均关于 p_β，即取 $J = 0$。

(a) 证明 $\mathbb{E}(O) = -\,\partial_J F|_{J=0}$ 且 $\mathrm{Var}(O) = -\,\partial_J^2 F\big|_{J=0}$。

(b) 第三累积量沿用同样模式定义为 $\kappa_3(O) := -\,\partial_J^3 F\big|_{J=0}$。以各阶矩 $\mathbb{E}(O^3)$、$\mathbb{E}(O^2)$ 和 $\mathbb{E}(O)$ 计算它，并证明它等于三阶中心矩 $\mathbb{E}[(O - \mathbb{E}O)^3]$。

(c) 对高斯变量 O，证明 $\log Z(J)$ 恰为 J 的二次函数，从而所有 $p \geq 3$ 的累积量均为零。用中心矩计算 κ_4，并检验它不是四阶中心矩。（要点：累积量衡量高阶矩无法按高斯模式由低阶矩决定的程度。）

(d) 验证式 (2.16)。

淬火平均。 在学习问题中，除了后验以外还有第二个随机来源：训练集本身。自由能等量依赖于抽取的是哪 n 个样本，且在 n 很大时预期会集中在对抽样取平均的值附近。物理学家把系统达到平衡之前即固定的随机性称为淬火无序，类比于合金在水中淬火后被冻结的杂质；对于后验而言，训练数据就是淬火无序。淬火自由能为

$$\mathbb{E}_{\mathrm{data}}[F] = -\mathbb{E}_{\mathrm{data}}[\log Z]. \tag{2.17}$$

[3] 译注：这一组能量累积量公式以 E 不显含 β 为前提。若按前文把先验吸收入 $E = \mathcal{L} - \beta^{-1}\log\pi$，则求导时还需计入 E 对 β 的显式依赖。

应该平均的是自由能而非配分函数，因为自由能是广延的，且其导数给出期望值。对 $\log Z$ 求平均通常很困难，退火近似交换了运算顺序：

$$\mathbb{E}_{\text{data}} \log Z \approx \log \mathbb{E}_{\text{data}} Z, \tag{2.18}$$

根据 Jensen 不等式，右侧是上界，而且常是一个好的近似。我们将在第 2.6 节使用它。精确处理途径是副本方法，附录 A 给出了概要；经典参考资料是 [26]。

2.4 物理学实例：伊辛模型

与热物理的类比为我们打开了一个装满成熟近似方法的工具箱。我们将在统计力学最著名的模型上展示其中两种方法：平均场近似和大 N 下的鞍点近似。关于本例的物理学，更深入的讨论可参见 [89, 第 1 章]。

模型。 设 Λ 为具有 N 个顶点和无向边 $\langle ij \rangle$ 的图；通常 Λ 是 D 维规则晶格，每个顶点具有相同数目 d 的邻居（对于超立方晶格，$d = 2D$）。每个顶点 i 上有一个自旋 $s_i \in \{\pm 1\}$。系统的状态是对所有 N 个自旋的一种选择，因此共有 2^N 个状态。一个状态的能量为

$$E(s) = -J \sum_{\text{边}\langle ij \rangle} s_i s_j - B \sum_{i=1}^{N} s_i. \tag{2.19}$$

耦合 $J > 0$ 有利于相邻自旋相互对齐，外磁场 B 则有利于自旋与它对齐。逆温度为 β 时，Boltzmann 分布为 $p_\beta(s) = e^{-\beta E(s)}/Z$，其中 $Z(\beta, J, B) = \sum_{s \in \{\pm 1\}^N} e^{-\beta E(s)}$。从量纲上看，只有 βJ 和 βB 这两个组合有影响。

描述一个状态的最简单的宏观量是它的磁化强度，即平均自旋：

$$m(s) = \frac{1}{N} \sum_{i=1}^{N} s_i \in [-1, 1]. \tag{2.20}$$

这是我们的第一个序参量例子：针对所要研究的问题，用一个数概括 N 维微观状态。这里要问的是自旋是否对齐（$|m|$ 接近 1，有序相）或不对齐（m 接近 0，无序相），以及这如何依赖于 β、J 和 B。

平均场近似。 我们希望把 2^N 个状态上的分布 $p_\beta(s)$ 推前为单变量 m 上的分布。相互作用项阻碍了这一过程，因为它将每个自旋与其特定邻居耦合。平均场近似用邻居的平均值代替每个自旋的邻居：假设每个自旋只感受到其余自旋的平均场，那么在邻居求和中可将每个 s_j 替换为 m，

$$\sum_{\langle ij \rangle} s_i s_j = \frac{1}{2} \sum_i s_i \underbrace{\sum_{j \sim i} s_j}_{\approx dm} \approx \frac{dm}{2} \sum_i s_i = \frac{Nd}{2} m^2. \tag{2.21}$$

（因子 1/2 补偿了对每条边的两次计数。）能量变成仅依赖于 m 的函数：

$$E(s) \approx -N \left(\frac{dJ}{2} m^2 + Bm \right). \tag{2.22}$$

对于低维晶格，这一近似不可控，因为自旋周围为数不多的邻居会与它一同涨落；但它在 $D \geq 2$ 时定性正确，在 $D \geq 4$ 时定量正确 [89, 第 1 章]。对于每个自旋都与其他全部自旋弱耦合的模型，这一近似变为精确；该模型称为 Curie–Weiss 磁体，将在第 5.1 节再次出现，作为神经网络平均场极限的原型。

熵与单变量化简。 由于能量只依赖于 m，对状态的求和可以按 m 的取值组织：

$$Z \approx \sum_{m} \Omega(m) e^{N\beta(\frac{dJ}{2}m^2+Bm)}, \qquad \Omega(m) := \#\{s : m(s)=m\} = \binom{N}{\frac{1+m}{2}N}, \tag{2.23}$$

因为磁化强度为 m 的状态恰好有 $\frac{1+m}{2}N$ 个向上自旋。Stirling 公式给出

$$\frac{1}{N}\log\Omega(m) \xrightarrow{N\to\infty} h(m), \quad h(m) := \log 2 - \frac{1-m}{2}\log(1-m) - \frac{1+m}{2}\log(1+m), \tag{2.24}$$

即磁化强度为 m 时每个格点的熵：它是与宏观值 m 相容的微观状态数的对数。$m=0$ 时熵最大，$h=\log 2$，几乎全部 2^N 个状态都位于这里[4]；$m=\pm 1$ 时熵为零，此时恰好只有一个状态。将对 m 的求和替换为积分（间距为 $2/N$），配分函数成为一维积分：

$$Z \approx \int_{-1}^{1} dm\, e^{-N\beta s(m)}, \qquad s(m) := -\frac{dJ}{2}m^2 - Bm - \beta^{-1}h(m). \tag{2.25}$$

函数 $s(m)$ 称为有效作用量，或固定 m 下的自由能密度：每个格点的能量减去温度乘以熵。我们已将问题从 N 个变量化简为一个变量。这是本节每类计算的一般形式：将微观分布推前到一个序参量，同时付出的代价是引入一个熵项，计数每个序参量值所对应的微观状态数。

鞍点。 在大 N 时，被积函数 $e^{-N\beta s(m)}$ 在 s 的极小点附近形成指数尖峰，积分由其中最低极小点附近宽度约为 $1/\sqrt{N}$ 的窗口支配。这是鞍点近似（也称 Laplace 方法），给出

$$\varphi(\beta,J,B) = -\frac{1}{N}\log Z \xrightarrow{N\to\infty} \beta \min_{m} s(m). \tag{2.26}$$

这正是第 2.3 节所预告的自由能最小化。极小点 $\bar m$ 是系统实际呈现的磁化强度。令 $\partial s/\partial m = 0$，并利用 $h'(m) = -\tanh^{-1}(m)$，得到

$$dJ\bar m + B = \beta^{-1}\tanh^{-1}(\bar m), \qquad \text{即} \quad \bar m = \tanh\big(\beta(dJ\bar m + B)\big). \tag{2.27}$$

这个超越方程最好用图解法求解（图 1）。依 β、J 和 B 的取值不同，它有一个解或三个解；有三个解时，外侧两个是 s 的极小点，中间一个是极大点。

自洽性（附注）。 式 (2.27) 还有另一种推导方式，这也是平均场理论通常出现的形式，我们将在第 5 节使用。考察单个自旋 s_i 所感受到的有效场：

$$B_i^{\mathrm{eff}} = -\frac{\partial E}{\partial s_i} = J\sum_{j\sim i} s_j + B \approx dJm + B. \tag{2.28}$$

处于该场中的单自旋配分函数为 $Z_i = \sum_{s_i=\pm1} e^{\beta B_i^{\mathrm{eff}} s_i} = 2\cosh\beta(dJm+B)$，平均值为 $\mathbb{E}(s_i) = \beta^{-1}\partial_B \log Z_i = \tanh\beta(dJm+B)$。若近似自洽，得到的平均值就必须等于输入的平均值，即 $m = \mathbb{E}(s_i)$，这正是式 (2.27)。先在平均环境中求解单体问题，再要求所得平均值与输入相符：这就是所有平均场理论的原型。

[4] 译注：这里应理解为状态集中于 $m=0$ 的邻域。对偶数 N，恰有 $m=0$ 的状态所占比例为 $2^{-N}\binom{N}{N/2} \sim \sqrt{2/(\pi N)} \to 0$，而非趋于一。

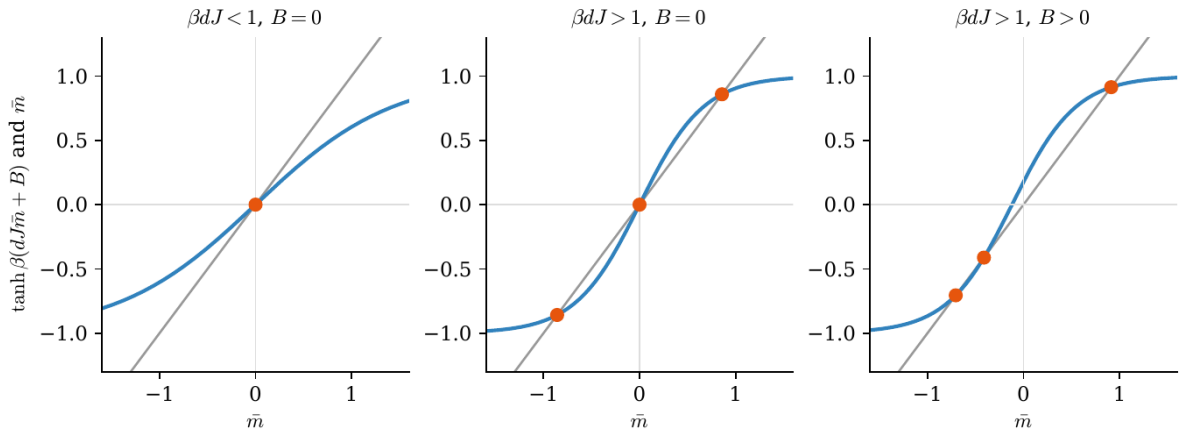


图 1: 平均场方程 (2.27) 的图解：$\tanh[\beta(dJ\bar{m}+B)]$ 与对角线的交点。左：高温，唯一解 $\bar{m}=0$。中：$B=0$ 的低温，三个解，其中 $\bar{m}=0$ 是 s 的极大点，$\pm\bar{m}$ 是简并极小点。右：$B>0$ 的低温，三个解，其中正值解为全局极小点。图中文字对照：三栏分别为 $\beta dJ<1, B=0$、$\beta dJ>1, B=0$ 和 $\beta dJ>1, B>0$；横轴为 $\bar{m}$，纵轴比较 $\tanh[\beta(dJ\bar{m}+B)]$ 与 $\bar{m}$。

2.5 相与相变

现在分析 $s(m)$ 的极小值结构随 β、J 和 B 变化的情况；这些极小值决定概率集中于何处。将熵作 Taylor 展开，$h(m)=\log 2 - m^2/2 - m^4/12 - \cdots$，得到作用量

$$s(m) \approx \text{常数} - Bm + \frac{1}{2}(\beta^{-1} - dJ)m^2 + \frac{\beta^{-1}}{12}m^4 + \cdots . \tag{2.29}$$

按照序参量的幂展开自由能称为 Landau 理论；下面的定性分析只依赖这种形式，不依赖背后的微观模型。

有序相与一级相变。 取 $dJ > \beta^{-1}$：此时耦合强于温度，式 (2.29) 的二次项系数为负，$s(m)$ 是双阱（图 2）。系统倾向有序，即相邻自旋对齐；但它们朝哪个方向对齐？磁场决定方向。$B<0$ 时全局极小值接近 $m=-1$，$B>0$ 时接近 $m=+1$，$B=0$ 时两个极小值完全简并。当 B 扫过 $B_c=0$，系统呈现的磁化强度从 $\bar{m}\approx -1$ 跳到 $\bar{m}\approx +1$。这就是一级相变。

这种相变的结构是普适的，因为它来自两个孤立极小值的交叉，与模型的具体细节无关。考虑期望磁化强度；根据式 (2.14)，它是自由能对磁场的导数：

$$\mathbb{E}(m) = \frac{1}{N}\sum_i \mathbb{E}(s_i) = -\frac{1}{\beta}\frac{\partial \varphi}{\partial B}. \tag{2.30}$$

在有限 N 下，s 的两个极小值是两个竞争相，$\mathbb{E}(m)$ 是它们磁化强度按概率加权的平均。当 $N\to\infty$ 时，鞍点近似将全部权重放到较低的极小值上，因此 $\mathbb{E}(m)$ 在 B_c 处出现不连续，而 φ 自身出现折角（图 3 左）。热力学极限下，自由能密度的一阶导数出现不连续，正是一级相变的定义。它的二阶导数对应磁化率

$$\chi := \frac{\partial \mathbb{E}(m)}{\partial B} = -\frac{1}{\beta}\frac{\partial^2 \varphi}{\partial B^2} = N\beta\,\mathrm{Var}(m), \tag{2.31}$$

它是一个峰，高度按 N 增长，宽度按 $1/N$ 缩小，形成一个初生的 delta 函数（图 3 右）。真正的非解析性只能在 $N=\infty$ 出现：在有限 N 时，配分函数是 B 的解析函数的有限和，所以一切都

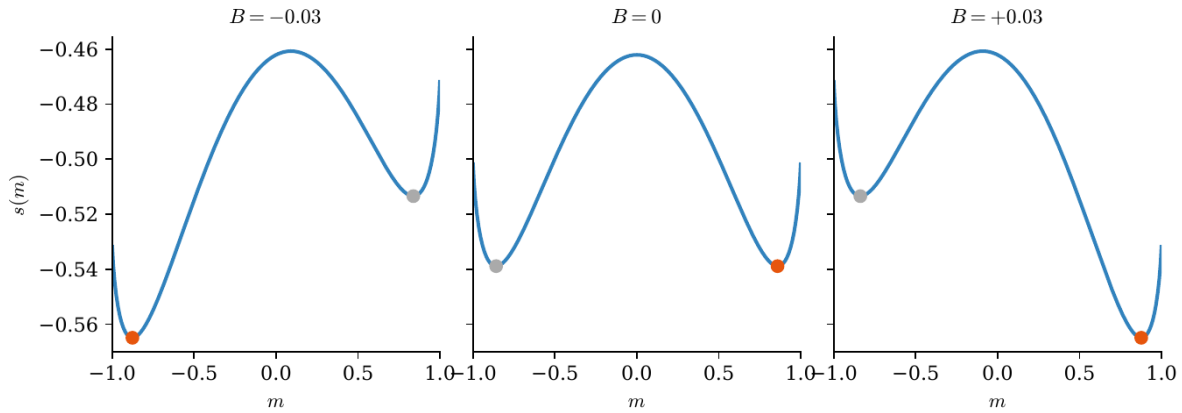


图 2: 式 (2.25) 的作用量 $s(m)$ 在有序相（$\beta dJ = 1.5$）中对负、零和正外场的响应。两个极小点随 B 倾斜；全局极小值（橙色）在 $B = 0$ 时从一侧切换到另一侧，被压低的极小值（灰色）以亚稳态形式保留。图中文字对照：三栏依次取 $B = -0.03, 0, +0.03$；横轴为 m，纵轴为 $s(m)$。

是光滑的，我们看到的是随着 N 增大而变尖锐的快速交叉。观察 χ 的峰是否随 N 增长而不是饱和，是区分真正相变与交叉的标准数值诊断方法。习题 2.2 将求出一般一级相变的这些曲线形状；讨论不断增大的模型中的“涌现能力”时，值得记住它们（第 7.6 节）。

亚稳性与滞后。 图 2 中被压低的极小值在不再是全局极小值后并不会消失。从那里开始、按照局域动力学（每次翻转一个自旋）演化的系统必须翻越势垒才能到达真正的极小值，这需要随 N 指数增长的时间。实际中，系统会停留在亚稳相，直到磁场远远越过 B_c，因而动力学观察到的相变落后于热力学相变。这就是我们熟悉的真实磁体中的磁滞。它也是在一级相变处必须谨慎处理第 2.1 节中“$\beta \leftrightarrow$ 训练时间”类比的原因；我们将在第 5.7 节以延迟泛化（顿悟，grokking）的形式再次遇到它。

二级相变。 一个 n 级相变是指当 $N \to \infty$ 时自由能密度的 n 阶导数不连续。伊辛模型也存在二级相变：固定 $B = 0$，当温度 $T = \beta^{-1}$ 穿过 $T_c = dJ$ 时发生（图 4）。这里没有东西相互交叉：位于 $m = 0$ 的单个势盆变平，然后分裂为两个对称势盆。式 (2.29) 中二次项系数在 T_c 处变号，极小点位于

$$\bar{m}^2 = 3(\beta dJ - 1) \approx 3\left(1 - \frac{T}{T_c}\right) \qquad (T \lesssim T_c), \tag{2.32}$$

所以序参量 $\bar{m} \propto (T_c - T)^{1/2}$ 的变化连续但不光滑；φ 和 $\partial_T \varphi$ 连续，而不连续出现在 $\partial_T^2 \varphi$（热容）中。点 $(T, B) = (T_c, 0)$ 是临界点。在它下方，两个有序状态 $\pm\bar{m}$ 恰为彼此的镜像，系统必须选取其中之一：这就是自发对称性破缺，即 $B = 0$ 时能量的 $\mathbb{Z}_2$ 对称性 $s \to -s$ 被状态打破。式 (2.32) 的指数 $1/2$ 是临界指数的一个例子。平均场理论在任意维度都预言这一数值，但在低维中它是错误的：$D = 2$ 时的精确值为 $1/8$（Onsager），而 $D = 1$ 时根本没有相变。$D \geq 4$ 时平均场指数变为精确。要理解其中的原因，需要使用重整化群，参见 [89]。

回到学习。 在第 2.1 节的贝叶斯模型中，自然的控制参数是 $n\beta$，即数据量或训练量。伊辛模型的对应过程是在固定 $B = 0$ 时扫描 β，它会经历二级相变。学习中的一级相变发生在两类定性不

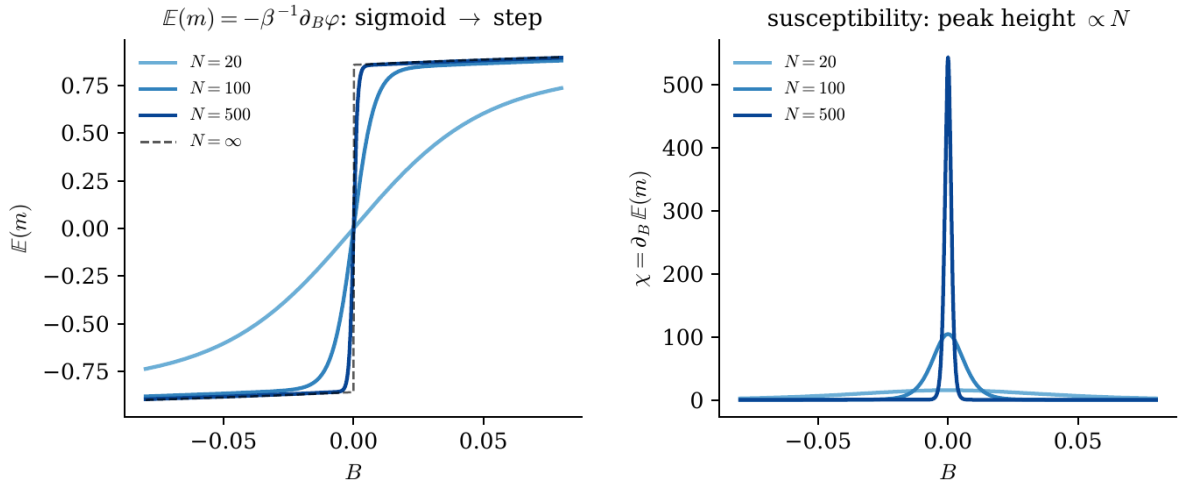


图 3: 平均场伊辛模型在 $\beta dJ = 1.5$ 时的一级相变特征，由有限 N 下的一维积分 (2.25) 计算得到。左：期望磁化强度随磁场变化，是宽度正比于 $1/N$ 的 sigmoid 曲线，并逐渐变为阶跃；右：磁化率 $\chi = \partial_B \mathbb{E}(m)$ 为高度正比于 N、宽度正比于 $1/N$ 的峰。图中文字对照：两图横轴均为 B，左图比较 $N = 20, 100, 500, \infty$，右图比较 $N = 20, 100, 500$；“sigmoid → step” 指从 S 形曲线趋向阶跃，“peak height $\propto N$” 指峰高正比于 N。

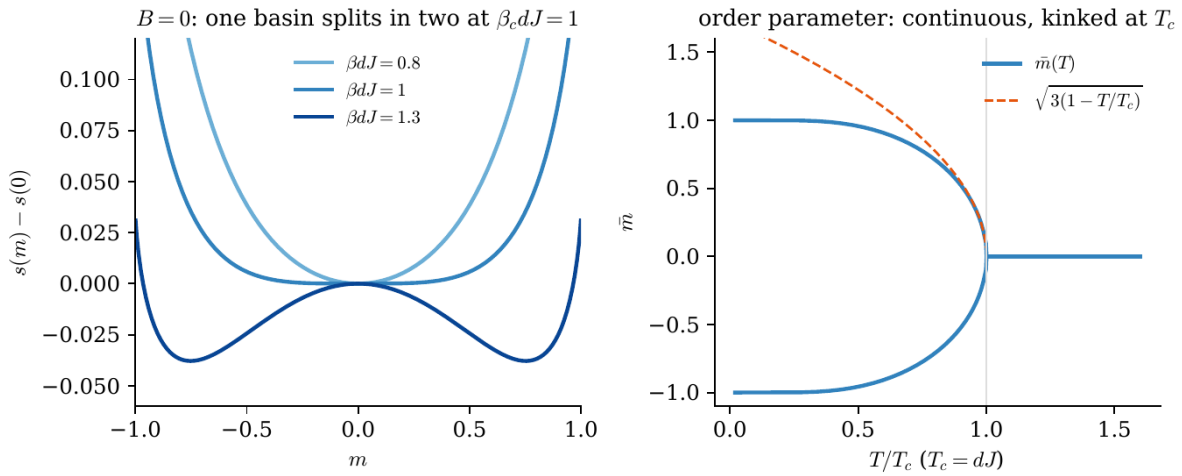


图 4: 平均场伊辛模型在 $B = 0$ 时的二级相变。左：高于、等于和低于 $T_c = dJ$ 时的作用量 $s(m)$；单个势盆变平并分裂为两个对称势盆。右：得到的磁化强度 $\bar{m}(T)$，在 T_c 处连续，但存在式 (2.32) 的平方根奇性（虚线）。图中文字对照：左图横轴为 m，纵轴为 $s(m) - s(0)$，三条曲线为 $\beta dJ = 0.8, 1, 1.3$；右图横轴为 T/T_c，纵轴为 $\bar{m}$，虚线为 $\sqrt{3(1 - T/T_c)}$。

同的解相互竞争时：一类受到熵的偏好，另一类受到数据的偏好；第 2.6 节的伊辛感知机是最清楚的例子。讨论它之前，下面的习题先确定有限 N 下任意一级相变的形态。

习题 2.2（一级相变剖析）。 （⋆）考虑一个配分函数具有形式 $Z(B)=\int d\theta\, e^{-NE(\theta,B)}$ 的任意系统，它依赖某个超参数 B。这里的 B 可以是逆温度、外场或第 2.6 节的负载 α；为保持设定的一般性，我们已将 β 吸收入 E。假设 $E(\theta,B)$ 恰有两个孤立极小点，分别位于 θ_1 和 θ_2。那么在大 N 下，积分由两个竞争相支配。设 U_1,U_2 是 θ_1,θ_2 的小邻域，

$$Z(B)\approx\int_{U_1}d\theta\, e^{-NE(\theta,B)}+\int_{U_2}d\theta\, e^{-NE(\theta,B)}=e^{-N\varphi_1(B)}+e^{-N\varphi_2(B)},\tag{2.33}$$

其中 $\varphi_i(B)=-N^{-1}\log\int_{U_i}d\theta\, e^{-NE(\theta,B)}=E(\theta_i,B)+o(1)$ 是两个势盆的自由能密度。进一步假设，当 B 越过临界值 B_c 时，两个极小值交叉：$\varphi_1(B_c)=\varphi_2(B_c)$，且 $\varphi_1'(B_c)\neq\varphi_2'(B_c)$，其中撇号表示 ∂_B。

(a) *占据*。证明系统位于第 i 个势盆的概率为

$$p_i(B)=\frac{e^{-N\varphi_i(B)}}{e^{-N\varphi_1(B)}+e^{-N\varphi_2(B)}},\tag{2.34}$$

并令 $\Delta B:=B-B_c$，作一阶展开后得到

$$p_2(B)\approx\frac{1}{1+e^{-N\Delta\varphi'\Delta B}},\qquad\qquad\Delta\varphi':=\varphi_1'(B_c)-\varphi_2'(B_c),\tag{2.35}$$

这是 $N\Delta\varphi'\Delta B$ 的 logistic 函数。系统在哪个 B 窗口中从一个势盆切换到另一个?

(b) *一阶导数*。由式 (2.33) 证明

$$\frac{\partial\varphi}{\partial B}\approx p_1(B)\varphi_1'(B_c)+p_2(B)\varphi_2'(B_c),\tag{2.36}$$

即各分支斜率按概率加权的平均。画出有限 N 与 $N=\infty$ 时的曲线：一个高度为 $\Delta\varphi'$ 的 sigmoid，逐渐变尖成为跳跃。φ 本身的折角是定义一级相变的不连续性。并直接由积分证明 $\partial_B\varphi=\mathbb{E}[\partial_B E(\theta,B)]$：发生跳跃的可观测量与控制参数共轭。当 $B=\beta$ 时它是能量，其跳变量是潜热；对于以 B 为磁场的伊辛模型，它是磁化强度。

(c) *二阶导数*。利用 $\partial_B p_1=-\partial_B p_2=-Np_1p_2\Delta\varphi'$（请验证），证明[5]

$$-\frac{\partial^2\varphi}{\partial B^2}=Np_1p_2(\Delta\varphi')^2-p_1\varphi_1''-p_2\varphi_2''.\tag{2.37}$$

画出此曲线。在 B_c 附近，$p_1p_2\approx1/4$，第一项是高度约为 $N(\Delta\varphi')^2/4$、宽度约为 $1/(N\Delta\varphi')$ 的峰，$N\to\infty$ 时收敛到 delta 函数。还需证明：当 $O(\theta)=\partial_B E(\theta,B)$ 不依赖 B 时，$-\partial_B^2\varphi=N\,\mathrm{Var}(O)\geq0$。（$B=\beta$ 时这是热容；对于伊辛磁场，它是磁化率。）

(d) *绘图*。取最小模型 $\varphi_1(B)=a(B-B_c)$、$\varphi_2=0$，对几个 N 值绘制 φ、$\partial_B\varphi$ 和 $-\partial_B^2\varphi$。（使用数值稳定的 $\log(e^x+e^y)$。）观察该峰随 N 增长而非饱和，是区分真正相变与光滑交叉的标准诊断。

[5]译注：原文在 (a) 中把 $\Delta\varphi'$ 定义为 B_c 处的固定斜率差。对于一般 B，精确导数需要使用 $\varphi_1'(B)-\varphi_2'(B)$；使用固定差值属于临界点附近的局部近似，除非另有条件。

2.6 伊辛感知机：学习中的一级相变

我们以一个学习问题的完整统计力学分析结束本节的物理部分；这个问题构造得与伊辛磁体平行。它是我们所知最简单的一个模型，其中更多数据会产生通向完美泛化的真正相变；它可追溯到 Györgyi[35]，参见 [26, 第 7 章]。下面以引导式习题给出；解答在附录 C 中，但请先尝试每个部分再阅读解答。

设定。 教师是一个固定的二值权重向量 $\theta^* \in \{\pm 1\}^N$。输入服从高斯分布 $x \sim \mathcal{N}(0, I_N)$，教师按下式给其标注：

$$y(x) = \operatorname{sign}(\theta^* \cdot x). \tag{2.38}$$

学生是另一个二值向量 $\theta \in \{\pm 1\}^N$，以同样方式猜测标签，即 $f_\theta(x) = \operatorname{sign}(\theta \cdot x)$。这个模型称为伊辛感知机，因为其权重取伊辛自旋的值。我们观察 n 个样本 (x^μ, y^μ)，其中 $y^\mu = y(x^\mu)$，并在均匀先验下按第 2.2 节的意义进行零温贝叶斯学习：学生正确分类时单样本损失为 0，错误时为 ∞，所以后验在所有正确分类每个样本的学生上均匀分布。教师和学生恰好在 $y(x)(\theta \cdot x) > 0$ 时对 x 给出相同结果，因此

$$p(\theta) \propto \prod_{\mu=1}^{n} \Theta\big(y^\mu(\theta \cdot x^\mu)\big), \qquad\qquad Z = \frac{1}{2^N} \sum_{\theta \in \{\pm 1\}^N} \prod_{\mu=1}^{n} \Theta\big(y^\mu(\theta \cdot x^\mu)\big), \tag{2.39}$$

其中 $\Theta(u) = 1$（$u > 0$），否则为 0。有了因子 $1/2^N$，Z 就是所有学生中与数据相容的比例。我们将取固定比值下 N, n 同时很大的极限；负载

$$\alpha := \frac{n}{N} \tag{2.40}$$

即每个参数对应的样本数，是问题的控制参数。

习题 2.3（伊辛感知机）。 $(\star)$

(a) *序参量是磁化强度。* 定义重叠 $R(\theta) = N^{-1}\theta \cdot \theta^* \in [-1, 1]$ 及对齐变量 $s_i := \theta_i \theta_i^* \in \{\pm 1\}$。证明 $R = N^{-1}\sum_i s_i$：重叠就是自旋 s_i 的磁化强度。学到教师意味着使它们磁化至 $R = 1$。

(b) *泛化误差。* 证明重叠为 R 的学生将一个新的高斯输入错误分类的概率是

$$\epsilon(R) = \frac{\arccos R}{\pi}. \tag{2.41}$$

[提示：将 x 投影到由 θ 和 θ^* 张成的平面上；投影是各向同性二维高斯分布，两个决策边界是交角为 $\arccos R$ 的直径。符号何时不一致？]

(c) *熵：与磁体相同的 h。* 证明重叠为 R 的学生数为 $\binom{N}{\frac{1+R}{2}N}$，故由 Stirling 公式，

$$\frac{1}{N}\log \#\{\theta : R(\theta) = R\} \longrightarrow h(R) = \log 2 - \frac{1-R}{2}\log(1-R) - \frac{1+R}{2}\log(1+R), \tag{2.42}$$

它与磁体的熵 (2.24) 完全相同，只需将 m 换为 R。

(d) 推前到一个变量。对数据集平均 Z。样本相互独立，每个样本被重叠为 R 的学生正确分类的概率是 $1-\epsilon(R)$，因此

$$\mathbb{E}_x Z = \frac{1}{2^N}\sum_{\theta}\big(1-\epsilon(R(\theta))\big)^n. \tag{2.43}$$

利用 (c) 将对 θ 的求和换成对 R 的积分，证明固定负载 α 且 N 很大时，

$$\mathbb{E}_x Z \approx \int_{-1}^{1} dR\, e^{-Ns(R)}, \qquad s(R) = \log 2 - h(R) - \alpha\log\big(1-\epsilon(R)\big). \tag{2.44}$$

这与磁体的式 (2.25) 完全对应：一个熵项计数状态，一个 “场” 项有利于对齐。现在使其对齐的场是数据，场强是负载 α。（平均 Z 而不是 $\log Z$ 即式 (2.18) 的退火近似。这里它保留所有定性结构，只轻微改变数值；附录 A 解释如何进行精确计算。）

(e) 绘图。对几个 α 值画出 $s(R)$ 并找出其临界点。你预期会发生相变吗？发生在哪个 α 值?

(f) 教师势盆。$R=1$ 是完全对齐的状态，此时学生就是教师。证明对于任意 α，$s(1)=\log 2$（熵为零，但数据代价也为零），且 $R=1$ 始终是局域极小值[6]：令 $\delta = 1-R$，偏离教师可获得约 $\frac{\delta}{2}\log(1/\delta)$ 的熵，但要付出数据拟合代价 $\alpha\epsilon \sim \alpha\sqrt{2\delta}/\pi$（展开 arccos），并且 $\sqrt{\delta} \gg \delta\log(1/\delta)$。这与磁体不同：在那里对齐状态位于一个光滑势阱底部，并不总是极小值。

(g) 内部势盆、交叉与相变。当 $\alpha=0$ 时，s 在 $R=0$ 处最小，且 $s(0)=0<s(1)$：无序的典型学生云占主导。随着 α 增大，这个内部极小点 $R^*(\alpha)$ 向 1 移动，其函数值上升。用数值方法求出两势盆交换主导地位的负载 α_c，满足 $s(R^*(\alpha_c)) = s(1)$。你应得到 $\alpha_c \approx 1.45$，此时内部极小点仍在 $R^* \approx 0.70$，即泛化误差 $\epsilon^* \approx 0.25$。由此得出：在 α_c 处，典型学生从 25% 错误率跳至零错误率，即发生通向完美泛化的一级相变。然后以 α 为控制参数与习题 2.2 联系：有限 N 时 $\partial_\alpha\varphi$ 和 $-\partial_\alpha^2\varphi$ 的形状如何？什么量起潜热的作用？最后，求出内部极小点完全消失的负载，并根据第 2.5 节的亚稳性讨论解释两者之间发生了什么。

(h) 对应词典。完成下表：

伊辛磁体	伊辛感知机
自旋 $s_i \in \{\pm 1\}$	对齐变量 $s_i = \theta_i\theta_i^* \in \{\pm 1\}$
磁化强度 m	重叠 R
熵 $h(m)$	熵 $h(R)$（相同函数）
使其对齐的场 B	?
扫过相变的调节参数	?
有序相 $\mathbb{E}(m) \approx \pm 1$	?
$\mathbb{E}(m)$ 作为 B 函数的跳跃	?

还需说明一个结构上的区别：在磁体中，两个竞争极小值由对称性联系；而此处它们是什么，(c) 的哪个成分使尖锐相变成为可能？（若权重位于球面，即 $\theta \in \mathbb{R}^N$、$|\theta|^2 = N$，且重叠为 R 的切片体积正比于 $(1-R^2)^{N/2}$，又会有什么变化？附录 A.3 给出了推导。）

[6]译注：按下文的平方根与熵项比较，这里要求 $\alpha > 0$。当 $\alpha = 0$ 时，$s(R) = \log 2 - h(R)$，从 $R=1$ 向内部移动反而会减小 s；原文的 “始终” 未排除这一端点。

2.7 与量子场论的比较

这个简短的小节是一份术语对应指南，主要面向高能物理或凝聚态物理背景的读者——如果“作用量”和“路径积分”对你来说比“后验”和“边缘似然”更熟悉，请继续阅读；其他读者可以放心跳过。

讲义中的几乎所有内容首先都属于欧几里得平衡统计力学：Boltzmann–Gibbs 形式的概率分布 $P \propto e^{-\beta E}$、配分函数和自由能。对于场论研究者，带源配分函数

$$Z[J] = \int \mathcal{D}\phi\, e^{-S[\phi]+\int J\phi} \tag{2.45}$$

是矩生成泛函；其对数生成连通关联函数（累积量）；作用量 S 编码系统的微观规则，二次作用量意味着自由（高斯）理论，其他部分则通过围绕它的微扰处理。在本讲义中，场 ϕ 的角色可以由网络权重 θ 担任，也可以由序参量担任，例如第 2.4 和 2.6 节中的磁化强度 m 或重叠 R；或者——最有用的情况——由网络函数 $f(x)$ 本身担任，此时输入 x 起时空坐标的作用。第 3.3 和 3.5 节将仔细构造对网络函数的泛函积分；具有量子场论背景的读者会发现许多以学习理论面貌出现的熟悉要素：Wick 定理、源、累积量和有效作用量。

如果你的直觉建立在 Lorentz 符号约定上，可以想象这里的一切都已经进行了 Wick 旋转。这里没有 $i/\hbar$：权重 e^{-S} 是实数且为正，与标准延拓之后相同：

$$Z_{\mathrm{QFT}} = \int \mathcal{D}\phi\, e^{\frac{i}{\hbar}S[\phi]} \xrightarrow{\tau=it} Z_{\mathrm{E}} = \int \mathcal{D}\phi\, e^{-S_{\mathrm{E}}[\phi]/\hbar}. \tag{2.46}$$

$\hbar$ 的作用——控制鞍点附近涨落大小的参数——在这里由温度、大宽度下的 $1/N$ 或大样本数下的 $1/n$ 担当。

当我们最终在第 6 节把训练动力学作为场论研究时，确实会出现一个真正的实时间形式——一个具有因果结构和响应场的轨迹路径积分。这是讲义中最接近 Lorentz 场论的对象，也正是非平衡统计力学的 Martin–Siggia–Rose 构造。

对于希望在学习理论参考文献之外另读物理学文献的读者：David Tong 的讲义 [90, 89, 88, 87] 分别为统计物理、统计场论、动力学理论和量子场论提供了平易近人的介绍；Lancaster 和 Blundell[50] 从概念出发温和引入量子场论；Altland 和 Simons[2] 搭建了通向凝聚态场论的桥梁（并包含第 6 节所用的 Langevin/MSRJD 内容）；Pathria[64] 是标准的研究生统计力学教材；Goldenfeld[33] 是相变和重整化群的经典著作；Zinn-Justin[99] 是泛函形式的百科全书式参考书。

3 初始化时的大宽度：高斯过程极限

接下来的几节讨论神经网络中的不同极限，其中某些参数变得很大。这些极限恰是物理和统计分析大显身手的地方。研究它们能够教给我们一些基本经验：应当（以及不应当）如何初始化网络，以及如何选择其他超参数。它还会导出解析可解的模型，这些模型展现了我们在实践中看到的许多性质：惰性与丰富学习、双下降、相变以及最优学习的标度律。关于这些内容的进一步教学参考资料，我们推荐 [71, 84, 69] 以及在线讲义 [37]。

本节从一个经典结果 [62, 52, 95, 36] 入手，考察固定深度和训练样本数下增加网络宽度的情况。现代神经网络比这里讨论的简单多层感知机更加复杂，但它们具有许多相同的特征。层归一化解决了大深度下的可训练性问题，但对丰富与惰性区域、特征学习以及超参数标度的分析仍然相关。例如参见第 5.5 节对 μP 的讨论。

3.1 记号

对神经网络及训练数据，我们使用如下记号：

- $\theta \in \mathbb{R}^P$：可训练的网络参数（权重、偏置）；
- $(x^\mu, y^\mu)_{\mu=1}^n$：训练数据样本，其中除非另有说明，$x^\mu \in \mathbb{R}^d$、$y^\mu \in \mathbb{R}$；
- $f_\theta : \mathbb{R}^d \to \mathbb{R}$：网络函数。

特别是对于多层感知机（MLP，也称 FCN，即全连接网络）：

- $\{z_i^{(\ell)}\}_{i=1}^{N_\ell}$：第 $\ell \in \{0, \dots, L+1\}$ 层的激活前量；
- L 为隐藏层数（深度），N_ℓ 为第 ℓ 层的宽度，$N_0 = d$ 且 $N_{L+1} = 1$。我们常取恒定的隐藏深度，即 $N_1 = \cdots = N_L = N$[7]；
- $\phi : \mathbb{R} \to \mathbb{R}$：激活函数（假设除第一层外各层相同）；
- 网络递推关系为

$$z_i^{(\ell)} = \begin{cases} \dfrac{1}{\sqrt{N_{\ell-1}}} \displaystyle\sum_{j=1}^{N_{\ell-1}} w_{ij}^{(\ell)} \phi(z_j^{(\ell-1)}) + b_i^{(\ell)}, & \ell \geq 2, \\ \dfrac{1}{\sqrt{d}} \displaystyle\sum_{j=1}^{d} w_{ij}^{(1)} x_j + b_i^{(1)}, & \ell = 1, \end{cases}$$

其中 $z^{(0)} = x$、$z^{(L+1)} = f$，参数为 $\theta = \{w^{(\ell)}, b^{(\ell)}\}_{\ell=1}^{L+1}$。显式因子 $1/\sqrt{N_{\ell-1}}$ 是一种归一化约定，第 3.2 节将解释它：引入这些因子后，所有权重与偏置都可取为 $O(1)$ 量级。

3.2 网络归一化

考虑深度为 L、层宽 N_ℓ 如第 3.1 节所述的全连接网络。假设固定 L 而将 N_ℓ 取为非常大。还假设网络随机初始化，所有权重和偏置独立地从方差为 $O(1)$ 的正态分布抽取：

$$w_{ij}^{(\ell)} \sim \mathcal{N}(0, \sigma_w), \qquad b_i^{(\ell)} \sim \mathcal{N}(0, \sigma_b), \tag{3.1}$$

其中 σ_w, σ_b 在宽度增大时固定。（这里以及全文中，$\mathcal{N}(0, \sigma)$ 表示方差为 σ 的高斯分布。让方差随层数变化不会改变下面的结果。）问题是如何对网络递推中的求和归一化，使激活前量从一层到下一层都保持 $O(1)$。由

$$z_i^{(\ell)} = \frac{1}{\sqrt{N_{\ell-1}}} w_i^{(\ell)} \cdot \phi(z^{(\ell-1)}) + b_i^{(\ell)} \tag{3.2}$$

（其中将 $w_i = (w_{i,1}, \dots, w_{i,N_{\ell-1}})$ 和 $z^{(\ell-1)} = (z_1^{(\ell-1)}, \dots, z_{N_{\ell-1}}^{(\ell-1)})$ 写作向量），得到

$$\begin{aligned} \mathrm{Var}(z_i^{(\ell)}) &= \frac{1}{N_{\ell-1}} \sum_{j=1}^{N_{\ell-1}} \mathrm{Var}(w_{ij}^{(\ell)}) \, \mathbb{E}\Big[\phi(z_j^{(\ell-1)})^2\Big] + \mathrm{Var}(b_i^{(\ell)}) \\ &= \sigma_w \cdot \frac{1}{N_{\ell-1}} \sum_{j=1}^{N_{\ell-1}} \left(\mathrm{Var}\big(\phi(z_j^{(\ell-1)})\big) + \mathbb{E}\Big[\phi(z_j^{(\ell-1)})\Big]^2 \right) + \sigma_b. \end{aligned} \tag{3.3}$$

[7] 译注：原文用语为 “constant hidden depth”，但所列等式固定的是隐藏层宽度；本句保留原文用语及等式。

这里我们以先前层为条件，并利用对相互独立且 X 均值为零、Y 任意的随机变量，$\mathrm{Var}(XY) = \mathrm{Var}(X)\mathbb{E}[Y^2]$，以及独立求和项的方差可加性。第二行中的平均仅涉及激活函数和前一层 $O(1)$ 量级的激活前量，因此当 $N_{\ell-1} \to \infty$ 时仍为 $O(1)$。（我们将在第 3.7 节使这一估计更精确。）故

$$\mathrm{Var}(z_i^{(\ell)}) \approx \sigma_w \cdot O(1) + \sigma_b = O(1). \tag{3.4}$$

前因子 $1/\sqrt{N_{\ell-1}}$ 是输入每个神经元的连接数（“输入扇入”）平方根的倒数，恰好使激活前量在大宽度下保持 $O(1)$。我们将其称为扇入归一化；这一方法可追溯到 20 世纪 90 年代 LeCun 及合作者的工作 [51]。在第 4 节它也称为 NTK 归一化；在第 5 节我们会见到另一种平均场归一化，其中输出层使用 $1/N$ 而非 $1/\sqrt{N}$。

备注（其他约定）。 通常实践及很多文献的约定是不在网络中写出显式前因子，而是用依赖宽度的方差进行初始化：

$$\widetilde{w}_{ij}^{(\ell)} := \frac{w_{ij}^{(\ell)}}{\sqrt{N_{\ell-1}}} \sim \mathcal{N}\left(0, \frac{\sigma_w}{N_{\ell-1}}\right). \tag{3.5}$$

在初始化时，这两种约定描述完全相同的网络函数分布：式 (3.5) 是参数空间上的变量替换，网络是关于 x 的相同函数。本节只涉及初始化，因此结果不受约定选择影响。然而在训练期间，两种约定不等价：梯度下降在参数空间坐标重标度下不具有不变性，我们将在第 4.3 节解释。将每个参数保持为 $O(1)$、并在网络函数中显式写出 N 的因子，可以清楚比较不同标度极限；这是本讲义自始至终使用的约定。阅读文献时，应预期 N 的因子可能写在方差中，并用式 (3.5) 转换。

3.3 高斯过程

均值函数为 μ、协方差核为 K 的高斯过程 $f : \mathbb{R}^m \to \mathbb{R}$ 是一个随机函数，使得在任意 p 个输入 $(x^1, \ldots, x^p) \in (\mathbb{R}^m)^p$ 上，其函数值构成的向量服从高斯分布：

$$\begin{pmatrix} f(x^1) \\ \vdots \\ f(x^p) \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu(x^1) \\ \vdots \\ \mu(x^p) \end{pmatrix}, \begin{pmatrix} K(x^1,x^1) & \cdots & K(x^1,x^p) \\ \vdots & \ddots & \vdots \\ K(x^p,x^1) & \cdots & K(x^p,x^p) \end{pmatrix} \right). \tag{3.6}$$

其中 $\mu : \mathbb{R}^m \to \mathbb{R}$ 和 $K : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}$ 是固定的确定性函数，控制 f 的任意一组取值的均值和协方差。函数 K 通常称为该过程的核，它是对称的：$K(x, x') = K(x', x)$。

令 “dx” 表示 $\mathbb{R}^m$ 上的一个测度（不一定是通常的 Lebesgue 测度）。如果作为积分核的 K 有逆 K^{-1}，满足

$$\int dx'\, K^{-1}(x, x')K(x', x'') = \delta(x - x''), \tag{3.7}$$

则高斯过程还具有一种 “物理学定义”。由于它使用多维泛函积分，并非完全严格。从数学角度看，最好把它当作启发式工具：它附带一套公理式运算，这些运算给出的实际结果均能够（也应当）由其他方式充分证明。不过，这些运算很直观，为量子场论工作者所熟悉，因此我们在此介绍这一形式。其思想是，正如单个高斯变量 z 具有概率测度

$$P(z) = \frac{1}{Z} e^{-\frac{1}{2}K^{-1}(z-\mu)^2}, \qquad Z = \int dz\, e^{-\frac{1}{2}K^{-1}(z-\mu)^2} = \sqrt{2\pi K}, \tag{3.8}$$

高斯过程 f 也具有一个（不严格的）测度：

$$P[f] = \frac{1}{Z}\exp\left[-\frac{1}{2}\int dx\,dx'\,(f(x)-\mu(x))K^{-1}(x,x')(f(x')-\mu(x'))\right],$$
$$Z \text{“=”} \quad \int \mathcal{D}f\,\exp\left[-\frac{1}{2}\int dx\,dx'\,(f(x)-\mu(x))K^{-1}(x,x')(f(x')-\mu(x'))\right]. \tag{3.9}$$

如果核及输入空间 $\mathbb{R}^m$ 上的测度理论足够良好，使得 K 可以对角化，具有离散正交归一本征函数基 $\{\phi_k(x)\}_{k=1}^{\infty}$ 和本征值 $\lambda_1 \geq \lambda_2 \geq \cdots > 0$（于是 K^{-1} 的本征值为 $1/\lambda_k$），那么 $P[f]$ 可以理解为无限维高斯分布。写出 $f(x)-\mu(x) = \sum_{k=1}^{\infty} a_k\phi_k(x)$，有

$$P[f] = \frac{1}{Z}e^{-\frac{1}{2}\sum_{k=1}^{\infty} a_k^2/\lambda_k}, \qquad Z = \prod_{k=1}^{\infty}(2\pi\lambda_k)^{1/2}. \tag{3.10}$$

物理形式的一个优点是能够系统地组织 $f(x)$ 的乘积的期望值。为简单起见令 $\mu = 0$（要推广到任意 μ，只需在下文平移 $f \mapsto f-\mu$）。取任意（足够良好的……）函数 $J : \mathbb{R}^m \to \mathbb{R}$，定义

$$Z[J] = \int \mathcal{D}f\, e^{-\frac{1}{2}\int dx\,dx'\,f(x)K^{-1}(x,x')f(x')+\int dx\,J(x)f(x)}. \tag{3.11}$$

对积分进行形式计算得

$$Z[J] = Z[0]\, e^{\frac{1}{2}\int dx\,dx'\,J(x)K(x,x')J(x')}. \tag{3.12}$$

于是期望值可以表示为导数，由式 (3.12) 进一步得到

$$\mathbb{E}[f(x^1)\cdots f(x^p)] = \frac{1}{Z[0]}\frac{\delta}{\delta J(x^1)}\cdots\frac{\delta}{\delta J(x^p)}Z[J]\Big|_{J=0} \tag{3.13}$$
$$= \sum_{\substack{\text{配对}\{i_1,i_2\}\cup\cdots\cup\{i_{p-1},i_p\}\\ =\{1,2,\ldots,p\}}}\ \prod_{j=1}^{p/2} K(x^{i_{2j-1}}, x^{i_{2j}}). \tag{3.14}$$

求和遍历 $\{1,\ldots,p\}$ 的所有两两配对；p 为奇数时和为零。式 (3.14) 在量子场论中称为 Wick 定理，在概率论中称为 Isserlis 定理（尽管这里的推导不严格，它本身是正确的）。

习题 3.1（Wick 定理）。 如果此前没有见过这个定理，请通过对式 (3.11) 配方推导式 (3.12)，再通过求导推导式 (3.14)。明确检验前两个情形：

$$\mathbb{E}[f(x^1)f(x^2)] = K(x^1,x^2),$$
$$\mathbb{E}[f(x^1)f(x^2)f(x^3)f(x^4)] = K^{12}K^{34} + K^{13}K^{24} + K^{14}K^{23},$$

其中 $K^{ij} = K(x^i,x^j)$。$p=6$ 时出现多少项?

物理形式的另一个优点是，它简洁地把高阶累积量与偏离高斯性联系起来。一般而言，随机变量 $X_1,\ldots,X_p$ 的 p 阶累积量 $\kappa_p(X_1,\ldots,X_p)$ 递归地由下式定义：

$$\mathbb{E}(X_1\cdots X_p) = \sum_{\substack{\{1,\ldots,p\}\text{ 的}\\ \text{划分}\Pi}}\ \prod_{\substack{\text{块}\{i_1,\ldots,i_k\}\\ \in\Pi}} \kappa_k(X_{i_1},\ldots,X_{i_k}). \tag{3.15}$$

例如，$\kappa_1(X)=\mathbb{E}(X)$，$\kappa_2(X_1,X_2)=\mathrm{Cov}(X_1,X_2)=\mathbb{E}(X_1X_2)-\mathbb{E}(X_1)\mathbb{E}(X_2)$。在物理学中，$\kappa_p$ 称为连通关联函数；它们衡量联合期望中不能由所涉变量子集的期望捕获的部分。对于高斯过程，

$$\kappa_2(f(x^1),f(x^2))=K(x^1,x^2),\qquad \kappa_p(f(x^1),\ldots,f(x^p))=0\quad \text{对所有}p>2, \tag{3.16}$$

这可直接从式 (3.14) 看出：$p>2$ 的联合期望都分解为成对项之积。因此，非零的高阶 κ_p 是非高斯性的度量。

在泛函积分形式中，这一点如下呈现。假设随机函数 $f:\mathbb{R}^m\to\mathbb{R}$ 由泛函概率分布

$$P[f]=\frac{1}{Z}e^{-S[f]} \tag{3.17}$$

支配，其中 $S:\{\text{函数}f\}\to\mathbb{R}$ 是某个泛函。（在物理学中 S 称为作用量。）和式 (3.11) 一样，我们可引入生成函数

$$Z[J]:=\int \mathcal{D}f\, e^{-S[f]+\int dx\, J(x)f(x)}\quad\Longrightarrow\quad \mathbb{E}[f(x^1)\cdots f(x^p)]=\frac{1}{Z[0]}\frac{\delta}{\delta J(x^1)}\cdots\frac{\delta}{\delta J(x^p)}Z[J]\bigg|_{J=0}. \tag{3.18}$$

累积量自然地以 $\log Z[J]$ 的导数形式出现，后者也称为（带源）自由能：

$$\kappa_p(f(x^1),\ldots,f(x^p))=\frac{\delta}{\delta J(x^1)}\cdots\frac{\delta}{\delta J(x^p)}\log Z[J]\bigg|_{J=0}, \tag{3.19}$$

这又形式上意味着

$$Z[J]=\exp\left(\sum_{p=1}^{\infty}\frac{1}{p!}\int dx^1\cdots dx^p\,\kappa_p(f(x^1),\ldots,f(x^p))J(x^1)\cdots J(x^p)\right), \tag{3.20}$$

即累积量的生成函数。[8]原作用量 $S[f]$ 是 $\log Z[J]$ 的逆 Legendre 变换（根据 $Z[J]$ 的定义）。[9]在累积量被假设很小时将其展开为形式级数，并为简单起见假设 $\mathbb{E}[f(x)]=0$，得到

$$\begin{aligned}S[f]=\frac{1}{2}&\int dx^1dx^2\,\kappa_2^{-1}(x^1,x^2)f(x^1)f(x^2)\\&-\int dx^1dx^2dx^3dy^1dy^2dy^3\,\kappa_2^{-1}(x^1,y^1)\kappa_2^{-1}(x^2,y^2)\\&\qquad\times\kappa_2^{-1}(x^3,y^3)\kappa_3(y^1,y^2,y^3)f(x^1)f(x^2)f(x^3)\\&-\int dx^1dx^2dx^3dx^4\,(\kappa_2^{-1})^4\big[\kappa_4-\kappa_3\kappa_2^{-1}\kappa_3\ \text{项}\big]f(x^1)f(x^2)f(x^3)f(x^4)-\cdots.\end{aligned} \tag{3.21}$$

物理学家可能会认出这是费曼图之和，其中累积量给出顶点。一个关键结构是：有效作用量中的 p 阶项只包含 κ_p 和更低阶累积量。特别地，f 是高斯过程当且仅当 $S[f]$ 是二次的；而由累积量度量的小幅非高斯偏差给出 $S[f]$ 的高阶项。

[8]译注：式 (3.20) 按原文保留；根据前面的 $Z[J]$ 定义，这里一般还需要因子 $Z[0]$，除非改用归一化后的 $Z[J]/Z[0]$。

[9]译注：这一句照原文翻译。一般地，$\log Z[J]$ 的 Legendre 变换给出有效作用量，不自动等于定义泛函积分时的原作用量；此处区分及下式适用条件有待核查。

3.4 NNGP 对应关系

神经网络理论中的一个经典结果是：固定深度、取大宽度，并采用第 3.2 节的扇入归一化时，初始化时的网络函数收敛到高斯过程。该定理在 20 世纪 90 年代针对单隐藏层网络提出 [62]，较近时期又被推广到更深的网络和不同架构，参见 [52, 95, 36]。

在这个定理中，网络函数的随机性来源于网络参数的随机初始化。可以想象随机初始化一群网络，再问网络函数会输出什么样的值。该结果之所以重要，一方面是因为它的普适性，另一方面是因为它为进一步分析训练提供输入，并使这种分析大为简化。

推导采用归纳法。这里仅对 MLP 简述。[10]为简单起见，假设偏置为零，且所有权重如式 (3.1) 一样具有相同的 $O(1)$ 方差 σ_w，并采用第 3.2 节的扇入归一化。在网络的第一层，激活前量是

$$z_i^{(1)}(x) = \frac{1}{\sqrt{d}} \sum_{j=1}^{d} w_{ij}^{(1)} x_j, \qquad\qquad w_{ij}^{(1)} \sim \mathcal{N}(0, \sigma_w). \tag{3.22}$$

固定 x 时，每个 $z_i^{(1)}(x)$ 都是 d 个独立同分布高斯变量（具有系数 x_j）之和，因而本身也是高斯的，且 $\mathbb{E}[z_i^{(1)}] = 0$，

$$\mathrm{Cov}\big(z_i^{(1)}(x), z_i^{(1)}(x')\big) = \frac{1}{d} \sum_{j,j'=1}^{d} \underbrace{\mathrm{Cov}(w_{ij}, w_{ij'})}_{\delta_{jj'}\sigma_w} x_j x'_{j'} = \sigma_w \frac{x \cdot x'}{d}, \tag{3.23}$$

因此 $z_i^{(1)}$ 是均值和核如下的高斯过程（GP）：

$$z_i^{(1)} \sim \mathcal{N}(0, K^{(1)}), \qquad\qquad K^{(1)}(x, x') = \sigma_w \frac{x \cdot x'}{d}. \tag{3.24}$$

在第二层，

$$z_i^{(2)} = \frac{1}{\sqrt{N_1}} \sum_{j=1}^{N_1} w_{ij}^{(2)} \phi(z_j^{(1)}), \qquad\qquad w_{ij}^{(2)} \sim \mathcal{N}(0, \sigma_w). \tag{3.25}$$

若以第一层激活前量为条件，同样的论证给出

$$z_i^{(2)} \sim \mathcal{N}(0, K^{(2)}), \qquad\qquad K^{(2)}(z^{(1)}, z^{(1)\prime}) = \sigma_w \frac{\phi(z^{(1)}) \cdot \phi(z^{(1)\prime})}{N_1}. \tag{3.26}$$

因而再次得到高斯过程。问题在于，如果不以激活前量为条件，这个 GP 的核就不再是确定性的，而自身成为随机变量：$\phi(z^{(1)}) \cdot \phi(z^{(1)\prime})$。这正是无穷宽度极限发挥作用之处。启发式地说，中心极限定理意味着式 (3.25) 左边中（非高斯!）随机变量乘积的和会在 $N_1 \to \infty$ 时变为高斯。更具体地，我们可以计算并约束其方差：

$$\mathrm{Var}\big(K^{(2)}(z^{(1)}, z^{(1)\prime})\big) = \frac{\sigma_w^2}{N_1^2} \mathrm{Var}\big(\phi(z^{(1)}) \cdot \phi(z^{(1)\prime})\big) \tag{3.27}$$

$$= \frac{\sigma_w^2}{N_1^2} N_1 \cdot \mathrm{Var}\big(\phi(z_1^{(1)})\phi(z_1^{(1)\prime})\big) \longrightarrow 0 \quad (N_1 \to \infty), \tag{3.28}$$

只要第一层激活前量为 $O(1)$（独立于 N_1），且激活函数足够合理（任何标准选择都可以）。因此当 $N_1 \to \infty$ 时，我们可以用期望代替随机核 $K^{(2)}$：

$$\bar{K}^{(2)}(x, x') := \sigma_w \, \mathbb{E}_{z_1^{(1)}(x), z_1^{(1)}(x') \sim \mathcal{N}(0, K^{(1)})} \big[\phi(z_1^{(1)}(x))\phi(z_1^{(1)}(x'))\big]. \tag{3.29}$$

[10]对于 Transformer，导致高斯过程、类似于“大宽度”的极限是注意力头数很大的极限。

此后每一层都类似。在无穷宽度下，核变得确定，并满足递推关系

$$\bar{K}^{(\ell)}(x,x') = \sigma_w\, \mathbb{E}_{u(x),u(x')\sim\mathcal{N}(0,\bar{K}^{(\ell-1)})}\big[\phi(u(x))\phi(u(x'))\big], \tag{3.30}$$

最终由 $\bar{K}^{(L+1)}(x,x')$ 支配网络函数 $f(x)$ 的高斯过程。

备注（精确核）。 对少数特殊激活函数，式 (3.30) 中的高斯期望可用闭式计算，得到显式的 NNGP 核。将前一层的核值记为 $K_{11}=\bar{K}^{(\ell-1)}(x,x)$、$K_{22}=\bar{K}^{(\ell-1)}(x',x')$ 和 $K_{12}=\bar{K}^{(\ell-1)}(x,x')$。对于 ReLU，$\phi(u)=\max(u,0)$，可得到 Cho 和 Saul 的反余弦核 [21]：

$$\bar{K}^{(\ell)}(x,x') = \frac{\sigma_w}{2\pi}\sqrt{K_{11}K_{22}}\big(\sin\vartheta + (\pi-\vartheta)\cos\vartheta\big), \qquad \cos\vartheta = \frac{K_{12}}{\sqrt{K_{11}K_{22}}}. \tag{3.31}$$

对于 sigmoid 型激活函数 $\phi=\mathrm{erf}$，Williams[93] 得到

$$\bar{K}^{(\ell)}(x,x') = \frac{2\sigma_w}{\pi}\arcsin\!\left(\frac{2K_{12}}{\sqrt{(1+2K_{11})(1+2K_{22})}}\right). \tag{3.32}$$

沿各层迭代这两个公式中的任意一个，只需几行代码就可以得到深层 ReLU 或 erf 网络的精确无限宽核。（推导式 (3.31)–(3.32) 是一项愉快但稍显漫长的高斯积分练习。）

习题 3.2（经验检验 NNGP 对应关系，实验）。 固定两个单位范数输入 $x,x'\in\mathbb{R}^d$，例如取 $d=8$、$x\cdot x'=0.5$。对宽度 $N\in\{3,30,300\}$，分别抽取 $M=10^4$ 次独立初始化，构造单隐藏层 erf 网络 $f(x)=N^{-1/2}\sum_{i=1}^{N}c_i\,\mathrm{erf}(a_i\cdot x/\sqrt{d})$，其中 $c_i,a_{ij}\sim\mathcal{N}(0,1)$（即 $\sigma_w=1$）。

(a) 画出系综中 $f(x)$ 取值的直方图，叠加方差由式 (3.32) 预测为 $\bar{K}^{(2)}(x,x)$ 的高斯密度；观察 $N=3$ 时明显非高斯的直方图如何收敛。

(b) 画出数对 $(f(x),f(x'))$ 的散点图，并将样本 2×2 协方差与预测的核矩阵比较。

(c) 对每次初始化记录式 (3.26) 的随机核 $K^{(2)}$，检验它在不同初始化间的方差按 $1/N$ 衰减（这是核变为确定性的机制）。

3.5 用泛函积分分析 NNGP

也可以通过泛函积分分析初始化时的大宽度。这只是对上面步骤的重新组织。我们用一个零偏置、单隐藏层网络说明方法，其中 $N_2=1$、$N_1=N$、$N_0=d$：

$$f(x) = \frac{1}{\sqrt{N}}\sum_{i=1}^{N} c_i\,\phi\!\left(\frac{1}{\sqrt{d}}a_i\cdot x\right), \qquad c_i\in\mathbb{R}, \qquad a_i,x\in\mathbb{R}^d. \tag{3.33}$$

所有权重的方差均为 σ_w，其初始分布为

$$P(c,a) = \frac{1}{Z}\exp\!\left(-\frac{1}{2\sigma_w}|c|^2 - \frac{1}{2\sigma_w}|a|^2\right). \tag{3.34}$$

要把此分布推前为第一层激活前量 $z_i=d^{-1/2}a_i\cdot x$ 的分布，可对 delta 函数积分：

$$P(c,z) = \int da\, P(c,a)\prod_i \delta\!\left(z_i(x) - \frac{1}{\sqrt{d}}a_i\cdot x\right). \tag{3.35}$$

这里 $z_i(x)$ 是 x 的任意函数，仅通过 delta 函数与网络值 $d^{-1/2}a_i \cdot x$ 联系。式 (3.35) 表示函数 z_i 上的泛函概率密度。为计算它，引入第二组 “Lagrange 乘子” 函数 $\widetilde{z}_i$，写成

$$\delta\left(z_i(x) - \frac{1}{\sqrt{d}} a_i \cdot x\right) = \int \mathcal{D}\widetilde{z}_i \, e^{i \int dx \, \widetilde{z}_i(x)(z_i(x) - \frac{1}{\sqrt{d}} a_i \cdot x)}, \tag{3.36}$$

然后先对 a 进行精确高斯积分，再对 $\widetilde{z}$ 积分：

$$P(c,z) = \frac{1}{Z} \int da \, \mathcal{D}\widetilde{z} \, \exp\left[-\frac{|c|^2}{2\sigma_w} - \sum_i \frac{|a_i|^2}{2\sigma_w} + i \sum_i \int dx \, \widetilde{z}_i(x) \left(z_i(x) - \frac{1}{\sqrt{d}} a_i \cdot x\right)\right] \tag{3.37}$$

$$= \frac{1}{Z} \int da \, \mathcal{D}\widetilde{z} \, \exp\left[-\frac{|c|^2}{2\sigma_w} + \sum_i \left\{-\frac{1}{2\sigma_w}\left(a_i + \frac{i\sigma_w}{\sqrt{d}} \int dx \, \widetilde{z}_i(x) x\right)^2 - \frac{\sigma_w}{2d} \int dx \, dx' \, \widetilde{z}_i(x)(x \cdot x')\widetilde{z}_i(x') + i \int dx \, \widetilde{z}_i(x) z_i(x)\right\}\right] \tag{3.38}$$

$$= \frac{1}{Z'} \int \mathcal{D}\widetilde{z} \, \exp\left[-\frac{|c|^2}{2\sigma_w} - \frac{\sigma_w}{2d} \sum_i \int dx \, dx' \, \widetilde{z}_i(x)(x \cdot x')\widetilde{z}_i(x') + i \sum_i \int dx \, \widetilde{z}_i(x) z_i(x)\right] \tag{3.39}$$

$$= \frac{1}{Z''} \exp\left[-\frac{|c|^2}{2\sigma_w} - \frac{1}{2\sigma_w} \sum_i \int dx \, dx' \, z_i(x) \left(\frac{x \cdot x'}{d}\right)^{-1} z_i(x')\right]. \tag{3.40}$$

我们清楚地看到第一层 GP 核 $K^{(1)}(x,x') = (\sigma_w/d) x \cdot x'$ 出现。

要将分布推前至网络输出 $f = N^{-1/2} c \cdot \phi(z)$，只需再次使用相同方法：

$$P(f) = \int dc \, \mathcal{D}z \, P(c,z) \, \delta\left(f(x) - \frac{1}{\sqrt{N}} c \cdot \phi(z(x))\right) \tag{3.41}$$

$$= \frac{1}{Z''} \int dc \, \mathcal{D}z \, \mathcal{D}\widetilde{f} \, \exp\left[-\frac{|c|^2}{2\sigma_w} - \frac{1}{2\sigma_w} \sum_i \int dx \, dx' \, z_i(x) \left(\frac{x \cdot x'}{d}\right)^{-1} z_i(x') + i \int dx \, \widetilde{f}(x) \left(f(x) - \frac{1}{\sqrt{N}} c \cdot \phi(z(x))\right)\right] \tag{3.42}$$

$$= \frac{1}{Z'''} \int \mathcal{D}z \, \mathcal{D}\widetilde{f} \, \exp\left[-\frac{1}{2\sigma_w} \int dx \, dx' \, \left(\frac{x \cdot x'}{d}\right)^{-1} z(x) \cdot z(x') - \frac{\sigma_w}{2N} \int dx \, dx' \, \widetilde{f}(x)\big[\phi(z(x)) \cdot \phi(z(x'))\big] \widetilde{f}(x') + i \int dx \, \widetilde{f}(x) f(x)\right]. \tag{3.43}$$

问题是，现在无法精确计算对 z 的积分，因为对于一般激活函数 ϕ，作用量对 z 不再是二次的。然而，当 $N \to \infty$ 时，可以将

$$\exp\left[-\frac{\sigma_w}{2N} \int dx \, dx' \, \widetilde{f}(x)\big[\phi(z(x)) \cdot \phi(z(x'))\big] \widetilde{f}(x')\right]$$

当作微扰，并以指数中的 $[\phi(z(x)) \cdot \phi(z(x'))]$ 在 z 的高斯测度

$$\exp\left[-\frac{1}{2\sigma_w} \int dx \, dx' \, \left(\frac{x \cdot x'}{d}\right)^{-1} z(x) \cdot z(x')\right]$$

（其核为 $K^{(1)}$）下的期望来近似该项。具体而言，所作近似具有以下形式：

$$\mathbb{E} e^{X/N} = e^{\mathbb{E}X/N} + O\left(\frac{\mathrm{Var}(X)}{N^2}\right). \tag{3.44}$$

在忽略 $O(1/N)$ 修正的精度下，这给出前一节的确定性核

$$\bar{K}^{(2)}(x,x') = \sigma_w \, \mathbb{E}_{z\sim\mathcal{N}(0,K^{(1)})}\big[\phi(z(x))\phi(z(x'))\big],$$

并得到

$$P(f) = \frac{1}{Z''''}\int \mathcal{D}\widetilde{f}\,\exp\!\left[-\frac{1}{2}\int dx\,dx'\,\widetilde{f}(x)\bar{K}^{(2)}(x,x')\widetilde{f}(x') + i\int dx\,\widetilde{f}(x)f(x)\right] + O\!\left(\frac{1}{N}\right) \tag{3.45}$$

$$= \frac{1}{Z''''}\exp\!\left[-\frac{1}{2}\int dx\,dx'\,f(x)\bar{K}^{(2)}(x,x')^{-1}f(x')\right] + O\!\left(\frac{1}{N}\right). \tag{3.46}$$

3.6 L/N

第 3.4 节的归纳论证在 $L=\infty$ 时不成立，有两个潜在问题。

首先，每一层都会出现一个 σ_w 因子。这些因子会累积，可能导致核消失（这还会导致训练时梯度消失），从而网络坍缩；也可能导致核无界（梯度也越来越大），此时网络会变得混沌，同样无法训练。我们将在第 3.7 节回到这一问题。通过仔细调参可以避免它。例如，在 $\phi(z)=z$ 的深线性网络（DLN）中，只需取 $\sigma_w=1$，这称为 LeCun 初始化 [51]；在 ReLU 网络中，正确选择则是 $\sigma_w=2$，称为 He 初始化 [38]。

即便根据激活函数调节 σ_w，使 GP 核平均而言从一层到下一层都保持 $O(1)$，非高斯性仍可能累积。结果是，控制网络有效行为的并非仅仅是典型规模为 N 的宽度，而是深宽比 L/N；这也包括大 N 时网络偏离纯高斯性的程度。

文献 [71] 的第 3–4 章用泛函积分方法分析了这种行为。特别是第 3 章研究了深线性网络这个简单例子，并给出了每层激活前量的高阶累积量的精确递推关系。对隐藏层宽度恒为 N 的网络，文中证明其领先非高斯性为

$$\begin{aligned}\kappa_4^{(L+1)} &= \left[\left(1+\frac{2}{N}\right)^{L} - 1\right]\left(\kappa_2^{(L+1)}\right)^2 \\ &= \left[\left(e^{2L/N}-1\right) - \frac{1}{N}\frac{2L}{N}e^{2L/N} + O(N^{-2})\right]\left(\kappa_2^{(L+1)}\right)^2,\end{aligned} \tag{3.47}$$

其中右侧的展开取有限 L/N、$L,N\to\infty$。[11]当 L/N 很小时，非高斯性保持很小但有限，量级为 L/N；当 L/N 很大时，$\kappa_4^{(L+1)}$ 发散，其他累积量也一样。网络输出在不同实例之间会发生混沌涨落，网络再次变得无法训练。

下面依照 [37, 第 2 讲]，在一个特殊情形下给出更直接的分析。考虑一个长度为 L 的 DLN，输入层和隐藏层的宽度均为 N：

$$\begin{aligned} z^{(\ell)} &= \frac{1}{\sqrt{N}} w^{(\ell)} z^{(\ell-1)}, & z^{(0)} &= x, \\ f(x) = z^{(L+1)} &= N^{-(L+1)/2} w^{(L+1)}\cdots w^{(1)} x, \end{aligned} \tag{3.48}$$

其中 $w_{ij}^{(\ell)}\sim\mathcal{N}(0,1)$，即 $\sigma_w=1$（且输入维数 $d=N$）。以 $z^{(\ell-1)}$ 为条件，向量 $z^{(\ell)}$ 是高斯的，$z^{(\ell)}\sim\mathcal{N}(0,N^{-1}I_N|z^{(\ell-1)}|^2)$，所以其范数满足递推关系

$$|z^{(\ell)}|^2 \sim |z^{(\ell-1)}|^2 \frac{\chi_N^2}{N}. \tag{3.49}$$

[11]译注：式 (3.47) 按原文保留。以单隐藏层、固定输入和独立标准高斯权重为例，若 κ_4 采用本讲义第 3.3 节的通常四阶累积量定义，则条件高斯计算给 $\kappa_4 = 6\kappa_2^2/N$，而该式在 $L=1$ 时给 $2\kappa_2^2/N$。是否采用了不同归一化仍需对照作者引用核实。

（回顾：χ^2_N 是 N 个独立同分布标准高斯变量平方和的分布。）将输入归一化为 $|x| = 1$，则递推关系意味着

$$|f(x)|^2 \overset{d}{=} \prod_{k=1}^{L+1} \frac{\chi^2_N}{N} = \exp\left[\sum_{k=1}^{L+1} (\log \chi^2_N - \log N)\right], \tag{3.50}$$

其中每个 χ^2_N 因子相互独立。当 N 很大时，$\log \chi^2_N - \log N = \mathcal{N}(-1/N, 2/N) + O(1/N^2)$，所以在 N, L 都很大且 L/N 固定时，

$$|f(x)|^2 \overset{d}{=} e^{\mathcal{N}(-L/N, 2L/N)}, \tag{3.51}$$

至多差高阶 $O(1/N^2)$ 修正。于是当 L/N 增大时，期望 $\mathbb{E}|f(x)| \to 0$，但方差及高阶累积量发散。

再次得到的经验是：

- $N \to \infty$、$L/N = 0$：高斯过程，不同层之间没有关联（并且如第 4 节所示，没有“特征学习”）。
- $N, L \to \infty$ 且 L/N 很小：关联受控，网络可训练（并且如后所见，训练中有特征学习）。今天开放权重的大语言模型中，$L/N \approx 0.005$–0.01；参见习题 3.3。
- $N, L \to \infty$ 且 L/N 很大：混沌且无法训练。

习题 3.3（现实中的深宽比）。 （⋆）查找几个开放权重语言模型系列——例如 GPT-2、Llama 系列、Qwen 系列——的深度 L（Transformer 块数）和宽度 N（模型或嵌入维数），并为每个模型计算 L/N。这一比值在不同系列、同一系列的不同尺寸、不同年份之间变化多少？所有人都在“关联受控”的窗口中训练吗？

3.7 混沌边缘

我们简要说明，如何调节初始化方差 σ_w, σ_b 等，使网络在经过大量层时行为稳定（第 3.6 节的第一个问题），对此的分析有时称为寻找“混沌边缘”。

这一术语可追溯到 20 世纪 80–90 年代的动力系统理论，指有序相与混沌相之间的边界。它在 2016 年前后被引入神经网络研究 [65, 75]。其思想是把逐层推进看作一个动力系统，进而问：对两个相近输入 x, x'，在什么超参数范围（σ_w, σ_b 等）内以及到达多大深度时，它们仍保持相近，既不 (a) 坍缩，也不 (b) 混沌发散（即没有关联）？这一分析大体上相当于确保式 (3.26)、(3.30) 的核递推既不坍缩，也不发散。如果从理论上仔细处理，可以构造深度超过 10000 层、仍能训练的基本网络（不使用层归一化!）[94]。

对于使用 ReLU 激活的 MLP，混沌边缘就是单独一点 $\sigma_w = 2, \sigma_b = 0$。稍微离开该点时，可以估计网络坍缩或发散的“临界深度” L_c，参见 [75]。对于使用其他激活函数的 MLP，混沌边缘更有意思。$\phi = \tanh$ 时的相图如图 5 所示。

控制临界深度（$L_c = -1/\log \chi_1$）的量 χ_1，是逐层核递推在其不动点处的导数，它衡量相近输入分离的快慢。重要的是，同一个 χ_1 还控制训练过程中梯度反向传播穿过网络时的大小。因此，初始化时的行为与训练期间的行为直接相关。下面我们转向训练。

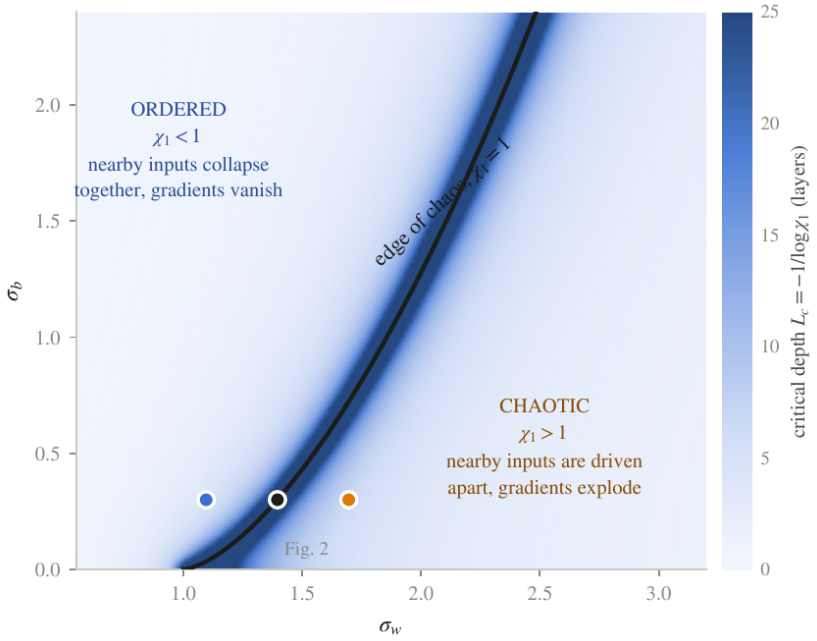


图 5: tanh 网络的有序 / 混沌相图，阴影表示网络可训练到的临界深度。图内左侧为有序区域：$\chi_1 < 1$，相近输入趋于坍缩，梯度消失；右侧为混沌区域：$\chi_1 > 1$，相近输入相互远离，梯度爆炸；曲线为混沌边缘 $\chi_1 = 1$。图中文字对照：横轴为 σ_w，纵轴为 σ_b，色标表示临界深度 $L_c = -1/\log \chi_1$（层数）；“ordered” “chaotic” “edge of chaos” 分别指有序、混沌与混沌边缘。原图内的 “Fig. 2” 为原图自身的标记，不指本译稿的图 2。

4 训练期间的神经切线核与大宽度

本节考虑按第 3.2 节随机初始化的网络的训练，以及它们在大宽度下的行为。我们将看到，当宽度趋于无穷时，这些网络实际上表现为线性模型：其参数 θ 始终不会远离初始化值 θ_0，因此

$$f_\theta(x) \approx f_\theta^{\text{lin}}(x) := f_{\theta_0}(x) + (\theta - \theta_0) \cdot \nabla_\theta f_{\theta_0}(x). \tag{4.1}$$

在适当条件下，网络本身也会以指数快的速度收敛到一个完美拟合训练数据的 “记忆网络”。启发式地说，这是因为如式 (4.1) 所示，许多参数的微小变化可以累加为网络值自身的 $O(1)$ 变化。尽管如此，网络不会经历相变或特征学习；下面将使此说法更精确。因此，大宽度区域（有限深度和有限训练数据下）称为惰性区域或 NTK 区域。（关于参数线性模型以及为何其训练相当于核岭回归的自成体系回顾，参见附录 B。）

尽管这一状态不描述使实际网络有趣的特征学习，理解它仍至少有两个原因：它是一个实在且解析可解的训练模型；它也准确地告诉我们，若要真正的特征学习，必须避免什么——我们会在第 5 节应用这一经验。

我们还强调第 3 节与当前分析之间的联系：两者涉及相同的大宽度极限。在初始化时，它导出高斯过程；在训练期间，我们将看到它导出具有惰性学习的线性模型，并在训练时间很长时再次收敛到高斯过程。

4.1 梯度流与 NTK

本节始终用连续时间梯度流近似 SGD（参见第 2.1 节），这涉及两个近似。首先，每一步用整个训练数据集 $\{(x^\mu, y^\mu)\}_{\mu=1}^n$ 更新，而非用小批次，使 SGD 变为 GD：

$$\theta_{k+1} - \theta_k = -\eta_{\text{GD}} \nabla_\theta \mathcal{L}_\theta(\{x^\mu, y^\mu\})|_{\theta=\theta_k}, \tag{4.2}$$

其中

$$\mathcal{L}_\theta = \mathcal{L}_\theta(\{x^\mu, y^\mu\}) := \sum_{\mu=1}^n \ell_\theta(x^\mu, y^\mu) \tag{4.3}$$

为完整经验损失。

其次，将学习率缩小为 $\eta_{\text{GD}} = \lambda^{-1}\eta$，并增加训练步数，令 $k = \lfloor \lambda t \rfloor$，其中 $t \geq 0$ 是连续的“时间”变量。$\lambda \to \infty$ 时，梯度下降收敛到梯度流

$$\dot{\theta} := \frac{d}{dt}\theta = -\eta \nabla_\theta \mathcal{L}_\theta. \tag{4.4}$$

本节的所有定理都可以扩展到 SGD，加入额外的误差项以约束 SGD 与梯度流（GF）之间的差异。（例如参见 [84, 第 19 章]。）

4.1.1 梯度流的几何

设 X 是光滑 Riemann 流形，具有非退化度规 $g = g_{ab}dx^a dx^b$、逆度规 $g^{-1} = g^{ab}\frac{\partial}{\partial x^a}\frac{\partial}{\partial x^b}$ 和函数 $h : X \to \mathbb{R}$。那么可定义关于 (h, g) 的梯度流：

$$\dot{x}^a(t) = -\eta g^{ab}\frac{\partial h}{\partial x^b}, \qquad \text{或抽象地：} \quad \dot{x} = -\eta g^{-1}(dh). \tag{4.5}$$

注意，没有逆度规（每个余切空间 T^*X 上的双线性型），这一方程就没有意义（不具坐标无关性）。逆度规用于把右侧的微分 $dh = (\partial_b h)_{b=1}^{\dim X}$ 转换为向量场 $g^{-1}dh$；后者才是在 X 上诱导流所需的几何对象。

在神经网络中，$X = \mathbb{R}^P$ 是参数 θ 的空间，$h = \mathcal{L}$ 是损失函数。为了定义 SGD、GD、GF 等，人们总是在参数空间中假设常数欧几里得度规 $g = \sum_{i=1}^P (d\theta^i)^2 = \delta_{ij}d\theta^i d\theta^j$。这是训练后模型某些最简单归纳偏置的来源，也是人们预期“特征”具有某种线性结构的原因。使用这一度规时，式 (4.5) 写成

$$\dot{\theta}^i = -\eta \delta^{ij}\partial_j \mathcal{L}_\theta. \tag{4.6}$$

现在回到 Riemann 流形的一般设定。设 $f : X \to Y$ 是两个流形之间的光滑映射，并且 $h : X \to \mathbb{R}$ 是函数 $h_Y : Y \to \mathbb{R}$ 的拉回，即 $h(x) = h_Y(f(x))$。令 $\{f^\alpha\}_{\alpha=1}^{\dim Y}$ 是 f 在 Y 的局部坐标 y^α 中的各分量。那么 X 上的逆度规在 Y 上诱导一个逆度规（称为其推前）：

$$f_*(g^{-1}) = f_*\left[g^{ab}\frac{\partial}{\partial x^a}\frac{\partial}{\partial x^b}\right] = \underbrace{g^{ab}\frac{\partial f^\alpha}{\partial x^a}\frac{\partial f^\beta}{\partial x^b}}_{g^{\alpha\beta}}\frac{\partial}{\partial y^\alpha}\frac{\partial}{\partial y^\beta}. \tag{4.7}$$

示意性地，$g^{\alpha\beta} = (Jg^{-1}J^T)$，其中 $J^\alpha{}_a = \partial f^\alpha/\partial x^a$ 是 f 的 Jacobian 矩阵。于是 X 上的梯度流在 Y 上诱导梯度流

$$\dot{y}^\alpha = -\eta g^{\alpha\beta}\frac{\partial h_Y}{\partial y^\beta}. \tag{4.8}$$

将这一点用于神经网络：$f:\mathbb{R}^P\to\mathbb{R}^n$ 是从参数到训练数据 (x^μ,y^μ) 上网络输出的映射，用标准记号即 $f^\mu(\theta)=f_\theta(x^\mu)$。损失函数确实是 $\mathbb{R}^n$ 上函数的拉回，因为它只通过训练数据上的网络值依赖参数 θ：

$$\mathcal{L}_\theta=\mathcal{L}^{(f)}(f(\theta)),\qquad\qquad \mathcal{L}^{(f)}(f):=\sum_{\mu=1}^{n}\ell(f^\mu,y^\mu). \tag{4.9}$$

参数空间中的梯度流推前后变成

$$\frac{d}{dt}f^\mu=-\eta\Theta^{\mu\nu}\frac{\partial\mathcal{L}^{(f)}}{\partial f^\nu},\qquad\qquad \Theta^{\mu\nu}=(J\delta^{-1}J^T)^{\mu\nu}=\sum_{i=1}^{P}\frac{\partial f_\theta(x^\mu)}{\partial\theta^i}\frac{\partial f_\theta(x^\nu)}{\partial\theta^i}. \tag{4.10}$$

函数值空间上的逆度规 $\Theta^{\mu\nu}$ 称为“神经切线核”或 NTK。这个名称由文献 [42] 提出，它也曾以另一个名称出现在 [24] 中。这里我们强调，对任何神经网络（事实上，对任何机器学习模型）而言，它都是一个完全自然的几何对象。

最后再提一点几何。令 $\delta_{\mu\nu}$ 为函数值空间中的标准欧几里得度规，$\delta^{\mu\nu}$ 为其逆。式 (4.10) 中出现的损失梯度 $\delta^{\mu\nu}\partial\mathcal{L}^{(f)}/\partial f^\nu$（与逆度规收缩）有时称为残差，记为 Δ^μ 或 r^μ。对于 MSE 损失，$\mathcal{L}^{(f)}=\frac{1}{2}\sum_{\mu=1}^n(f^\mu-y^\mu)^2=\frac{1}{2}\delta_{\mu\nu}(f^\mu-y^\mu)(f^\nu-y^\nu)$。于是残差就是训练数据上的函数值与真实值之差：

$$\Delta^\mu:=\delta^{\mu\nu}\partial\mathcal{L}^{(f)}/\partial f^\nu=f^\mu-y^\mu. \tag{4.11}$$

注意 y^μ 为常数，梯度流方程可改写为

$$\frac{d}{dt}\Delta^\mu=-\eta\underbrace{\Theta^{\mu\rho}\delta_{\rho\nu}}_{\Theta^\mu{}_\nu}\Delta^\nu. \tag{4.12}$$

学过规范理论的读者可能会认出这是关于一个 $n\times n$ 矩阵值联络 $\eta\Theta^\mu{}_\nu$ 的平行移动方程。如果知道 Θ 对时间的依赖（通常远非易事，见下方习题），其解是一个时间排序指数：

$$\Delta^\mu(t)=\left[\mathcal{P}\exp\left(-\eta\int\Theta(t)\,dt\right)\right]^\mu{}_\nu\Delta^\nu(0). \tag{4.13}$$

习题 4.1（从链式法则得到 NTK）。 仅用链式法则直接推导函数值 f^μ 的流方程 (4.10)，不需要几何。（几何推导解释了为什么 $\Theta^{\mu\nu}$ 这样的对象必然出现；链式法则则表明它只需三行就会出现。）

习题 4.2（核移动得有多快？）。 证明 NTK 的时间导数满足

$$\frac{d}{dt}\Theta^{\mu\nu}=-\eta\big[\nabla_\theta f^\mu\cdot\nabla_\theta^2 f^\nu\cdot\nabla_\theta f^\rho\big]\frac{\partial\mathcal{L}^{(f)}}{\partial f^\rho}+(\mu\leftrightarrow\nu), \tag{4.14}$$

其中 $\nabla_\theta^2 f^\nu=\nabla_\theta^2 f_\theta(x^\nu)$ 是 Hessian 矩阵。对 Hessian 作界最终会导出下文第 4.3 节的 NTK 不变定理。

4.2 特征

Jacobian 矩阵 $J^{\mu}{}_{i} = \partial f^{\mu}/\partial\theta^{i}$ 衡量训练数据上的函数值如何依赖网络权重的微小变化。假设参数多于训练数据，其奇异值分解为

$$J = USV^{T}, \qquad S = \begin{bmatrix} \mathrm{diag}(s_1, \ldots, s_n) & 0_{n\times(P-n)} \end{bmatrix}. \tag{4.15}$$

右奇异向量（V 的列）定义了参数空间中的自然模式，左奇异向量（U 的列）则是函数值空间中的自然模式——这里的“自然”是相对于网络输出如何依赖权重而言的。n 个左奇异向量连同其奇异值 s_i，可以抽象地视为网络已经学到的特征。特征学习的一个常见定义是：这些奇异向量与奇异值在训练中发生变化。

也可以通过 NTK 等价地分析特征。按矩阵形式，

$$\Theta = JJ^{T} = US^{2}U^{T}, \tag{4.16}$$

其本征向量是特征向量，本征值为 $\{s_i^2\}$。因此，当 NTK 在训练中变化时，就发生了特征学习。

备注。 学习理论其他部分中出现的一个密切相关的“对偶”对象是参数空间 $\mathbb{R}^P$ 上的 Fisher 信息度规。它的经验形式为

$$\mathcal{F} := J^{T}J = f^{*}(\delta), \tag{4.17}$$

即函数值空间上常数欧几里得度规经网络函数拉回参数空间的结果。其坐标表达式为

$$\mathcal{F}_{ij} = \frac{\partial f^{\mu}}{\partial\theta^{i}}\delta_{\mu\nu}\frac{\partial f^{\mu}}{\partial\theta^{j}}.$$

Fisher 度规的本征值为 $(s_1^2, \ldots, s_n^2, \underbrace{0, \ldots, 0}_{P-n})$，当 $P > n$（参数多于训练数据点）时自动退化。这是奇异学习理论的出发点之一。

4.3 大宽度下的常数 NTK

现在来到本节的主要理论结果和简化。假设 MLP 的深度 L 和训练数据数目 n 固定，令所有隐藏层宽度趋于无穷。我们假设隐藏层宽度均以相似方式标度，$N_L, N_{L-1}, \ldots, N_1 \approx N \to \infty$，并按照第 3.2 节的标准方式初始化网络。我们希望证明，对于几乎所有的训练数据样本：

- 在整个训练过程中，NTK $\Theta^{\mu\nu}$ 保持不变，至多有随 $N \to \infty$ 而消失的修正；
- 网络本身线性化：在任意训练时刻 t，$f_{\theta(t)}(x) = f_{\theta_0}(x) + (\theta(t) - \theta_0)\cdot\nabla_{\theta}f_{\theta_0}(x)$。

严格推导涉及一些技术细节，我们请读者参考 [24, 42]、[71, 第 11 章]、[84, 第 20 章] 中从不同角度给出的完整论证；这里仅概述结果背后的关键思想。另见 [37, 第 3 讲]。

为简化讨论，令偏置为零，网络变为

$$f_{\theta}(x) = z^{(L+1)}(x), \qquad z_i^{(\ell)} = \frac{1}{\sqrt{N_{\ell-1}}}\sum_{j} w_{ij}^{(\ell)}\phi(z_j^{(\ell-1)}), \qquad w_{ij}^{(\ell)} \sim \mathcal{N}(0, \sigma_w), \tag{4.18}$$

采用第 3.2 节的扇入归一化，权重为 $O(1)$。

NTK 的大小。 首先要估计 NTK 在大宽度下的大小，因为它决定学习率必须如何标度。由链式法则，关于第 ℓ 层权重的梯度是一个外积：

$$\frac{\partial f}{\partial w_{ij}^{(\ell)}} = \frac{1}{\sqrt{N_{\ell-1}}}\beta_i^{(\ell)}\phi(z_j^{(\ell-1)}), \qquad \beta_i^{(\ell)} := \frac{\partial f}{\partial z_i^{(\ell)}}, \tag{4.19}$$

其中反向传播的灵敏度 $\beta^{(\ell)}$ 满足 $\beta^{(L+1)}=1$，以及

$$\beta_i^{(\ell)} = \phi'(z_i^{(\ell)})\frac{1}{\sqrt{N_\ell}}\sum_k w_{ki}^{(\ell+1)}\beta_k^{(\ell+1)}. \tag{4.20}$$

NTK 是对各层求和：

$$\begin{aligned}\Theta^{\mu\nu} &= \sum_{\ell=1}^{L+1}\sum_{i,j}\frac{\partial f^\mu}{\partial w_{ij}^{(\ell)}}\frac{\partial f^\nu}{\partial w_{ij}^{(\ell)}} \\ &= \sum_{\ell=1}^{L+1}\underbrace{\left[\sum_i \beta_i^{(\ell)}(x^\mu)\beta_i^{(\ell)}(x^\nu)\right]}_{B_{\mu\nu}^{(\ell)}}\underbrace{\left[\frac{1}{N_{\ell-1}}\sum_j \phi(z_j^{(\ell-1)}(x^\mu))\phi(z_j^{(\ell-1)}(x^\nu))\right]}_{\to \bar{K}_{\mu\nu}^{(\ell)}/\sigma_w}.\end{aligned} \tag{4.21}$$

第二个方括号是 $N_{\ell-1}$ 项的平均。初始化且宽度很大时，大数定律将它替换为 $\bar{K}_{\mu\nu}^{(\ell)}/\sigma_w$，即式 (3.30) 的高斯过程核在两个输入上计算的值，其量级为 $O(1)$。（$\ell=1$ 时，这个方括号恰为 $x^\mu\cdot x^\nu/d$，即 $\bar{K}_{\mu\nu}^{(1)}/\sigma_w$。）第一个方括号可通过反向运行同样的递推处理。定义

$$\dot{\bar{K}}_{\mu\nu}^{(\ell)} = \dot{\bar{K}}^{(\ell)}(x^\mu,x^\nu) := \mathbb{E}\big[\phi'(z_i^{(\ell-1)}(x^\mu))\phi'(z_i^{(\ell-1)}(x^\nu))\big] \qquad (\text{任意固定 } i), \tag{4.22}$$

对于合理的激活函数，其量级为 $O(1)$。利用初始化时权重 $w^{(\ell+1)}$ 与其下各层所有变量的独立性，得到 $B_{\mu\nu}^{(\ell)} \approx \sigma_w \dot{\bar{K}}_{\mu\nu}^{(\ell+1)} B_{\mu\nu}^{(\ell+1)}$，以及 $B_{\mu\nu}^{(L+1)}=1$，因此

$$\mathbb{E}[\Theta^{\mu\nu}] \approx \sum_{\ell=1}^{L+1}\sigma_w^{L-\ell}\dot{\bar{K}}_{\mu\nu}^{(L+1)}\cdots\dot{\bar{K}}_{\mu\nu}^{(\ell+1)}\bar{K}_{\mu\nu}^{(\ell)}. \tag{4.23}$$

这是 $L+1$ 项之和，每项都是 $O(1)$，完全没有 N 的因子：在扇入归一化下，NTK 在大宽度时为 $O(1)$，每一层都有相同量级的贡献。（式 (4.23) 是无限宽 NTK 的标准递推式 [42]。）根据式 (4.10)，$O(1)$ 的学习率 η 会使函数值 f^μ 在单位时间内发生 $O(1)$ 变化，正是我们所需要的；在这种约定下不需要随宽度重标度 η。对于单隐藏层网络 $f = N^{-1/2}\sum_i c_i\phi(a_i\cdot x)$，可以手算检验：

$$\Theta^{\mu\nu} = \frac{1}{N}\sum_{i=1}^{N}\left[\phi(a_i\cdot x^\mu)\phi(a_i\cdot x^\nu) + c_i^2\phi'(a_i\cdot x^\mu)\phi'(a_i\cdot x^\nu)\, x^\mu\cdot x^\nu\right] = O(1), \tag{4.24}$$

它是 N 个 $O(1)$ 项的平均。（此处及以下把第一层因子 $1/\sqrt{d}$ 吸收入输入 x，因为 d 固定。）

说明：如何标度学习率。 刚才使用的规则是一般性的，我们将在第 5 节再次使用。当 $N\to\infty$ 时，必须保持为 $O(1)$ 的是网络值的运动 $\frac{d}{dt}f^\mu = -\eta\Theta^{\mu\nu}\partial\mathcal{L}^{(f)}/\partial f^\nu$，因为拟合数据的是这些量。因此，先求出 NTK 随 N 的标度，再选择 η 使 $\eta\Theta = O(1)$。在扇入归一化下，$\Theta=O(1)$ 且 $\eta=O(1)$；在第 5 节的平均场归一化下，$\Theta = O(1/N)$，η 必须按 N 增长。

其他参数约定只是变量替换，可以通过同一规则比较。假设网络中不写前因子，并如式 (3.5) 用 $\widetilde{w}^{(\ell)} = w^{(\ell)}/\sqrt{N_{\ell-1}} \sim \mathcal{N}(0,\sigma_w/N_{\ell-1})$ 初始化。关于欧几里得度规 $\sum(d\widetilde{w})^2$ 的梯度流，与关于

$\sum(dw)^2$ 的梯度流不同。在变量替换下，第 4.1.1 节的逆度规 δ^{ij} 在每个第 ℓ 层的块中获得因子 $N_{\ell-1}$，因此原坐标中的流为 $\dot{w}^{(\ell)} = -\eta N_{\ell-1}\partial\mathcal{L}/\partial w^{(\ell)}$。在 $\widetilde{w}$ 坐标中计算的 NTK 相应变大：用式 (4.21) 的各层贡献表示，$\widetilde{\Theta} = \sum_\ell N_{\ell-1}\Theta^{(\ell)}$，因此要使 f 发生 $O(1)$ 运动，需取 $\widetilde{\eta} \sim 1/N$。所以，重标度参数等价于按层重标度学习率；只有逐层匹配学习率，两种约定才定义相同的训练动力学。例如，在 $\widetilde{w}$ 约定下使用单一学习率 $\widetilde{\eta} \sim 1/N$ 时，隐藏层的运动与扇入归一化相同，但输入连接数 d 不随 N 增长的第一层实际上被冻结了。比较不同论文的学习率时，应先将参数化互相转换；系统处理见 [96]。

注意：估计式 (4.23) 取固定深度 L 和固定数据数 n。NTK 随深度按 L 增长，$n \times n$ 矩阵 Θ 的算子范数随 n 增长，因此对于深网络或大数据集，学习率必须相应缩小，而且下面的常数 NTK 结论需要 n, L 相对于 N 保持较小。

Hessian 很小。 为说明训练期间 NTK 近似不变，我们考察其时间导数；根据习题 4.2，它受网络函数 Hessian 的算子范数约束：

$$\frac{d}{dt}\Theta \lesssim \eta\,\|\nabla_\theta^2 f\|\,\|\Theta\|\,|\Delta|. \tag{4.25}$$

Hessian 是一个非常大但很稀疏的矩阵；在扇入归一化下，其算子范数很小。我们遵循 [37, 第 3 讲]，简述单隐藏层（$L = 1$）、一维输出的情形。写成

$$f_\theta(x) = \frac{1}{\sqrt{N}}\sum_{i=1}^{N} c_i\phi(a_i \cdot x), \qquad c_i \in \mathbb{R}, \qquad a_i \in \mathbb{R}^d, \tag{4.26}$$

Hessian 分解为块，每个隐藏神经元对应一个块：

$$\nabla_\theta^2 f_\theta(x) = \bigoplus_{i=1}^{N}(\nabla_\theta^2 f)_i, \qquad (\nabla_\theta^2 f)_i = \frac{1}{\sqrt{N}}\begin{bmatrix} 0 & \phi'(a_i\cdot x)x^T \\ \phi'(a_i\cdot x)x & c_i\phi''(a_i\cdot x)xx^T \end{bmatrix}. \tag{4.27}$$

块对角矩阵的算子范数是各块算子范数的最大值。每个块的大小固定为 $(d+1)\times(d+1)$，只含 $O(1)$ 量级的量（至少在初始化时），并有显式因子 $1/\sqrt{N}$。因此

$$\|\nabla_\theta^2 f\| = \max_{i=1,\dots,N}\|(\nabla_\theta^2 f)_i\| = O\!\left(\frac{1}{\sqrt{N}}\right) \qquad (N \to \infty). \tag{4.28}$$

有理由预期此界在训练过程中继续成立，再多做一些工作也可以证明（但这里不做）。它也适用于任意固定深度的网络。更精细的分析会跟踪涨落项之间的抵消，将所得核漂移界改进到 $O(1/N)$；粗略的 $O(1/\sqrt{N})$ 已足以支撑这个论证。

将各部分合在一起。 首先，参数总体移动不远。由 $\dot{\theta} = -\eta\sum_\mu \Delta^\mu\nabla_\theta f^\mu$，有

$$|\dot{\theta}|^2 = \eta^2\left|\sum_{\mu=1}^{n}\Delta^\mu\nabla_\theta f^\mu\right|^2 \le \eta^2|\Delta|^2|\nabla_\theta f|^2 \le \eta^2 n|\Delta|^2\|\Theta\| = O(1), \tag{4.29}$$

其中 $|\nabla_\theta f|^2 = \sum_\mu \Theta^{\mu\mu} = \operatorname{tr}\Theta$。于是由均值定理，对某个 $\bar{t} \in [0,t]$ 有 $\theta(t) - \theta_0 = t\dot{\theta}(\bar{t})$，并且

$$|\theta(t) - \theta_0| = O(1) \qquad \text{对任意固定 } t. \tag{4.30}$$

将 $O(1)$ 的总位移分摊到 $P \approx Nd$ 个参数上，意味着每个单独权重仅移动 $O(1/\sqrt{N})$：相对于其 $O(1)$ 的初始值，每个权重几乎不变。其次，核被冻结。由式 (4.25) 和 (4.28)，

$$\Theta(t) - \Theta(0) \leq t\|\dot{\Theta}(\bar{t})\| \lesssim t\eta\|\nabla_\theta^2 f\|\,\|\Theta\|\,|\Delta| = O\left(\frac{1}{\sqrt{N}}\right), \tag{4.31}$$

因此当 $N \to \infty$ 时，$O(1)$ 的核 Θ 变成常数。第三，网络线性化。由带余项的 Taylor 定理，

$$f_\theta(x) - f_{\theta_0}(x) = \nabla_\theta f(x)|_{\theta_0} \cdot (\theta - \theta_0) + \frac{1}{2}(\theta - \theta_0) \cdot \nabla_\theta^2 f(x)\big|_{\bar{\theta}} \cdot (\theta - \theta_0) \tag{4.32}$$

其中 $\bar{\theta}$ 位于 θ_0 和 θ 的连线上。令 $\theta = \theta(t)$，利用式 (4.30) 和 (4.28)，二次项受以下量约束：

$$\frac{1}{2}(\theta - \theta_0) \cdot \nabla_\theta^2 f(x)\big|_{\bar{\theta}} \cdot (\theta - \theta_0) \leq \frac{1}{2}\|\nabla_\theta^2 f\|\,|\theta - \theta_0|^2 = O\left(\frac{1}{\sqrt{N}}\right) \cdot O(1). \tag{4.33}$$

因此当 $N \to \infty$ 时，线性近似变为精确，尽管线性项以及网络函数本身仍发生 $O(1)$ 变化。用文字说：每个神经元对输出有 $O(1/\sqrt{N})$ 的影响，因此每个权重的 $O(1/\sqrt{N})$ 变化可以合成 f 的 $O(1)$ 变化，而如此小的变化不会改变特征 $\nabla_\theta f$。

4.4 惰性学习

当 NTK 在训练中保持不变时——这一情形经常令人困惑地被称为 NTK 区域——网络经历所谓的“惰性学习”。它不学习特征，因为 NTK 的本征值 s_μ^2 和本征向量 u_μ 按构造保持不变。尽管如此，网络函数仍以指数快的速度收敛到训练数据：由常数 Θ 下的式 (4.12)，得到

$$\Delta^\mu(t) = (e^{-\eta t\Theta})^\mu{}_\nu \Delta^\nu(0), \tag{4.34}$$

其中回顾 $\Delta^\mu(t) = f^\mu - y^\mu = f_{\theta(t)}(x^\mu) - y^\mu$。将残差写在 NTK 本征基中，$\Delta = \widehat{\Delta}^\mu u_\mu$，可见

$$\widehat{\Delta}^\mu(t) = e^{-\eta t s_\mu^2}\widehat{\Delta}^\mu(0). \tag{4.35}$$

每个特征以特征时间尺度 $t_\mu \approx 1/(\eta s_\mu^2)$ 被学到。

习题 4.3（测试点上的惰性预测）。 证明在任意测试点 x（不必是训练数据的一部分）上，

$$f_{\theta(t)}(x) = f_{\theta_0}(x) - \Theta(x, x^\mu)\Theta^{-1}_{\mu\nu}(\mathbf{1} - e^{-\eta t\Theta})^\nu{}_\rho \Delta^\rho(0), \tag{4.36}$$

其中 $\Theta(x, x^\mu) = \nabla_\theta f(x) \cdot \nabla_\theta f(x^\mu)$ 是测试—训练输入对的 NTK（它与训练—训练 NTK $\Theta^{\mu\nu}$ 一样在训练期间保持不变）。

由习题 4.3 可知，训练结束 $t \to \infty$ 时，网络满足

$$f_{\theta_\infty}(x) = f_{\theta_0}(x) - \Theta(x, x^\mu)\Theta^{-1}_{\mu\nu}\big(f_{\theta_0}(x^\nu) - y^\nu\big). \tag{4.37}$$

它是初始化时高斯过程 $f_{\theta_0}(x)$ 的仿射线性变换，因而仍是高斯过程。容易检验新均值与协方差为

$$\begin{aligned} \mathbb{E}[f_{\theta_\infty}(x)] &= \Theta^{x\mu}\Theta^{-1}_{\mu\nu}y^\nu, \\ \mathrm{Cov}\big[f_{\theta_\infty}(x), f_{\theta_\infty}(x')\big] &= K^{xx'} - 2\Theta^{x\mu}\Theta^{-1}_{\mu\nu}K^{\nu x'} + \Theta^{x\mu}\Theta^{-1}_{\mu\nu}K^{\nu\rho}\Theta^{-1}_{\rho\sigma}\Theta^{\sigma x'}, \end{aligned} \tag{4.38}$$

其中 $K^{xx'} = K(x, x')$、$\Theta^{x\mu} = \Theta(x, x^\mu)$，等等。

4.5 小结

到目前为止我们看到：在扇入归一化（第 3.2 节）下，权重和学习率 η 均为 $O(1)$，当宽度 N 很大时，

$$\|\Theta\| \sim |\nabla_\theta f|^2 \sim 1, \qquad \|\nabla_\theta^2 f\| \sim \frac{1}{\sqrt{N}}, \qquad |f_\theta - f_{\theta_0}| \sim 1,$$
$$|\theta - \theta_0| \sim 1 \ \text{（即每个权重 } N^{-1/2}\text{）}, \tag{4.39}$$

这迫使 Θ 成为常数，网络关于其参数线性化。

如果发生以下任一情形，这些结论全部失效：

- 深度 L 同样很大，且 L/N 非零（见 [71, 第 11 章]）；
- 数据样本数 n 变大，且 n/N 非零；
- 学习率变大。

对于现代神经网络，L 或 n 较大都是有趣的情形！

习题 4.4（数值实验：惰性网络）。 （$\star$）本实验以及其在习题 5.3 中的延续，将在扇入与平均场两种归一化下训练一个小网络，并以数值方法检验第 4、5 节的论断。该设置约需 60 行 NumPy 代码，数秒即可运行；请复现后再修改。

*起始模型。*输入为一维：$n = 30$ 个等距训练点 $x^\mu \in [-2, 2]$，目标来自一个双神经元教师 $y(x) = 2\tanh(3x) - \frac{3}{2}\tanh(x)$。学生是单隐藏层 tanh 网络

$$f(x) = \frac{1}{N^\gamma}\sum_{i=1}^{N} c_i \tanh(a_i x), \qquad c_i, a_i \sim \mathcal{N}(0,1), \qquad N = 300, \tag{4.40}$$

采用全批梯度下降训练，损失为 $\mathcal{L} = \frac{1}{2}\sum_\mu (f(x^\mu) - y^\mu)^2$，残差为 $\Delta^\mu = f(x^\mu) - y^\mu$。这里取扇入指数 $\gamma = \frac{1}{2}$，学习率 $\eta = 0.02$，训练 4×10^4 步。需要监控的经验 NTK 是 $n \times n$ 矩阵

$$\Theta^{\mu\nu} = \frac{1}{N^{2\gamma}}\sum_{i=1}^{N}\Big[\tanh(a_i x^\mu)\tanh(a_i x^\nu) + c_i^2\big(1 - \tanh^2(a_i x^\mu)\big)\big(1 - \tanh^2(a_i x^\nu)\big)x^\mu x^\nu\Big]. \tag{4.41}$$

(a) *它能拟合。*训练网络并检查损失是否变小。（网络是过参数化的；拟合本身并非有趣的部分。）

(b) *初始化。*使用约 200 个随机种子，绘制固定输入（如 $x = 1$）处 $f_0(x)$ 的直方图。你应看到一个 $O(1)$ 的高斯分布，即第 3.4 节的高斯过程；两个输入上的样本协方差应与 tanh GP 核一致。

(c) *核冻结。*对 $N \in \{30, 100, 300, 1000\}$（每个值用几个种子），记录 $\|\Theta_{\text{end}} - \Theta_0\|/\|\Theta_0\|$ 并在双对数坐标下对 N 作图。预期它衰减，斜率介于 $-1/2$（式 (4.31) 保证的界）与 -1（典型测量）之间。也记录相对参数位移 $|\theta_{\text{end}} - \theta_0|/|\theta_0|$，并与式 (4.30) 比较。

(d) *逐模态。*对角化 Θ_0，在半对数坐标下对若干 k 绘制 $|(U^T\Delta)_k(t)|$：得到斜率为 $-\eta s_k^2$ 的直线，特征以 $t_k = 1/(\eta s_k^2)$ 的时间尺度被学习，最大本征值最先被学习，如式 (4.35) 所示。与贝叶斯版本习题 4.5(b) 比较。

(e) *预测。*将训练后的函数在新测试点上的值，与冻结核预测式 (4.36) 比较。

4.6 大宽度下的贝叶斯学习：核学习

到目前为止，我们考虑通过梯度流（作为 SGD/GD 的近似）训练的大宽度 MLP。我们发现，它们的 NTK 保持不变，且长时间分布是式 (4.38) 给出的高斯过程。

假设考虑同一个大宽度网络，但在经验 MSE 损失 $\mathcal{L}(\theta) = nL_n(\theta) = \frac{1}{2}\sum_{\mu=1}^{n} |f(x^\mu) - y^\mu|^2$ 上改用贝叶斯推断来“训练”。（回顾第 2.1 节，从实际角度讲这意味着用 Langevin 动力学训练。）我们预期得到贝叶斯后验

$$P(\theta) = \frac{1}{Z} e^{-\beta \mathcal{L}(\theta)} \pi(\theta), \qquad \pi(\theta) \propto e^{-\frac{1}{2\sigma_w}|\theta|^2}, \tag{4.42}$$

其中先验 $\pi(\theta)$ 是式 (3.1) 的 $O(1)$ 方差高斯分布，网络采用第 3.2 节的扇入归一化。

我们希望把分布推前到网络函数 $f_\theta(x)$。在大宽度下，先验的推前就是第 3.4 节熟悉的高斯过程；如第 3.5 节那样用泛函积分表示，它变为

$$\pi[f] = \frac{1}{Z'} e^{-\frac{1}{2}\int dx\, dx'\, f(x) K^{-1}(x,x') f(x')}, \tag{4.43}$$

其中 $K(x,x') = \bar{K}^{(L+1)}(x,x')$ 是最终层的 GP 核。由于损失显式地是网络值的函数，我们立即得到长时间训练后的分布：

$$P[f] = \frac{1}{Z''} \exp\left[-\frac{1}{2} \left(\beta \sum_{\mu=1}^{n} (f(x^\mu) - y^\mu)^2 + \int dx\, dx'\, f(x) K^{-1}(x,x') f(x') \right) \right]. \tag{4.44}$$

注意，这里的作用量关于函数值是二次的，因此它仍是一个高斯过程！

习题 4.5（贝叶斯惰性学习：从高斯后验到核岭回归）。 （⋆）第 4.3 节中的大宽度惰性梯度流自行解出：NTK 冻结，残差的第 k 个核本征模态按 $e^{-\eta s_k^2 t}$ 衰减，因而在特征时间 $t_k = 1/(\eta s_k^2)$ 被学到。这里推导同一陈述的贝叶斯学习版本，让 β 扮演训练时间的角色。限制到训练值 $\mathbf{f} = (f(x^1), \ldots, f(x^n))$ 时，先验为高斯分布，协方差是核矩阵 $\widehat{K}^{\mu\nu} := K(x^\mu, x^\nu)$，故训练值上的后验为

$$p(\mathbf{f}) \propto \exp\left[-\frac{1}{2} \mathbf{f}^T \widehat{K}^{-1} \mathbf{f} - \frac{\beta}{2} |\mathbf{f} - \mathbf{y}|^2 \right]. \tag{4.45}$$

(a) *后验均值。*指数是二次型，所以后验为高斯分布，一切都可以通过配方得到。证明训练值的后验均值为 $\boldsymbol{\mu} = \widehat{K}(\widehat{K} + \beta^{-1} I_n)^{-1} \mathbf{y}$。

(b) *本征模态。*将核对角化，$\widehat{K} u_k = \lambda_k u_k$，并逐模态证明

$$u_k \cdot \boldsymbol{\mu} = \frac{\lambda_k}{\lambda_k + \beta^{-1}} u_k \cdot \mathbf{y} = \frac{\beta \lambda_k}{1 + \beta \lambda_k} u_k \cdot \mathbf{y}. \tag{4.46}$$

由此得出：随着 β 增大，初始化时 GP 核的本征模态逐个被学到；第 k 个模态在特征尺度 $\beta_k = 1/\lambda_k$ 处开启，大本征值模态最先开启（谱偏置）。

(c) *与梯度流比较。*将它与式 (4.35) 的 $\widehat{\Delta}^k(t) = e^{-\eta s_k^2 t} \widehat{\Delta}^k(0)$ 即 $t_k = 1/(\eta s_k^2)$ 并列，问二者何处相同、何处不同？有两点需要注意：数据量（或逆噪声）与训练时间之间的对应 $\beta \leftrightarrow \eta t$；以及两个滤波器的不同形状：关于 β 的幂律 $1/(1+\beta\lambda_k)$ 与关于 t 的指数 $e^{-\eta s_k^2 t}$（比较习题 B.5）。另请注意，贝叶斯计算使用 GP 核 K，动力学计算使用 NTK Θ：这是同一网络的两个不同冻结核。

(d) 预测。证明函数的完整后验仍是一个高斯过程，

$$P[f] \propto \exp\left[-\frac{1}{2}\int dx\, dx'\, [f(x)-\mu(x)]\Sigma(x,x')^{-1}[f(x')-\mu(x')]\right], \tag{4.47}$$

其均值及协方差为

$$\mu(x) = \sum_{\mu,\nu} K(x,x^\mu)\big(\widehat{K}+\beta^{-1}I_n\big)^{-1}_{\mu\nu} y^\nu,$$
$$\Sigma(x,x') = K(x,x') - \sum_{\mu,\nu} K(x,x^\mu)\big(\widehat{K}+\beta^{-1}I_n\big)^{-1}_{\mu\nu} K(x^\nu,x').$$

后验均值是岭参数为 β^{-1} 的核岭回归（附录 B.4），而 $\beta\to\infty$ 会精确插值数据。[提示：指数关于 f 是二次的；配方，并用 Woodbury 恒等式联系两种自然的答案形式。]

这些方程体现了有时称为核回归的计算，其岭参数为 $\beta^{-1}=T$。（附录 B.4 在不使用贝叶斯方法的情况下，为有限线性模型推导了相同公式。）如果训练样本足够稠密，均值可用未训练核表示为近似积分：

$$\mu(x) \approx \int dx'\, dx''\, K(x,x')\big(K+(n\beta)^{-1}\,\mathrm{id}\big)^{-1}(x',x'')y(x''). \tag{4.48}$$

在 K 的本征基中写出数据“真实值” $y(x)=\sum_k y_k\phi_k(x)$，其本征值按 $\lambda_1\ge\lambda_2\ge\cdots$ 排列，可得

$$\mu(x) = \sum_{k=1}^{\infty}\frac{\lambda_k}{\lambda_k+(n\beta)^{-1}} y_k\phi_k(x) \approx \sum_{k:\lambda_k\gtrsim(n\beta)^{-1}} y_k\phi_k(x). \tag{4.49}$$

这就是惰性学习的贝叶斯版本。给定 n,β，数据分布中满足 $\lambda_k\gtrsim(n\beta)^{-1}$ 的“模态”被网络学习，其余模态被投影掉。

回顾在贝叶斯背景下，重标度的逆温度 $n\beta$ 应发挥与 SGD/GD 训练时间大致类似的作用。我们可以在这里显式看到这一点。例如，在 SGD/GD 惰性学习中，学习 NTK 模态 s_μ^2 的特征时间为 $t\approx 1/(\eta s_\mu^2)$（见式 (4.35)）；相应地，在贝叶斯惰性学习中，学习 GP 模态所需的最小逆温度为 $\beta n\approx 1/\lambda_k$。

5 平均场标度

第 3、4 节分析的是同一个大宽度极限：采用扇入归一化（第 3.2 节），权重和学习率均为 $O(1)$，并在固定深度和数据的情况下令宽度 $N\to\infty$。初始化时，网络收敛到高斯过程；训练中 NTK 冻结，网络线性化，且按照第 4.2 节的定义没有学到特征。人们很容易得出无穷宽度意味着惰性的结论。本节的要点是：事实并非如此；惰性是参数化选择的结果，而非宽度本身的结果。对输出层归一化额外改变一个 $\sqrt{N}$ 因子，会产生一个不同但同样良好定义的无穷宽度极限：在其中，网络从零开始，单个权重发生 $O(1)$ 位移，NTK 随时间演化，并且真正学到特征。

这个不同的极限称为平均场极限。其名称类比于统计物理中的经典设定：一个具有弱全连接耦合的相互作用粒子系统，其 $N\to\infty$ 行为受一个自洽“平均场”支配。我们先解释物理学家所说的平均场理论（第 5.1 节），接着针对单隐藏层网络详细展开类比（第 5.2 节），并观察第 4 节的 NTK 图景如何变化（第 5.3 节）。最后讨论若干实际应用，包括插值标度、μP 和这一框架实际的用途（第 5.4–5.5 节）。

单隐藏层网络的平均场极限由四个研究组独立且基本同时构建 [56, 19, 72, 81]；我们的处理借鉴了全部四项工作。教学性介绍见 [84, 第 20 章] 和 [37, 第 4 讲]。

5.1 物理学中的平均场理论

“平均场理论” 是统计力学中最古老、最简单的近似方案之一：用每个自由度感受到的涨落环境的平均值（一个宏观序参量）代替环境，然后重新计算该平均值并要求自洽。对于大多数系统，这是不可控近似，但往往非常成功，参见 [89, 第 1 章]。然而，存在一类模型——具有弱全连接耦合的模型——在其中该近似在 $N \to \infty$ 时变为精确；我们将看到，平均场标度下的网络正是这类模型。

5.1.1 热身：Curie–Weiss 磁体

Curie–Weiss 磁体是第 2.4 节伊辛模型在完全图上的版本：每个自旋都耦合到其他所有自旋，耦合缩小为 J/N，从而单个自旋受到的总作用以及总能量分别保持 N^0 与 N^1 量级。令 $J = 1$，能量式 (2.19) 变为

$$E_N(s) = -\frac{1}{2N}\sum_{i,j=1}^{N} s_i s_j - B\sum_{i=1}^{N} s_i = -N\left(\frac{m^2}{2} + Bm\right), \qquad m := \frac{1}{N}\sum_i s_i. \tag{5.1}$$

第二个等式是精确的，而非近似：在完全图上能量只通过磁化强度依赖自旋。与晶格模型的平均场能量 (2.22) 比较，令 $dJ \to 1$。因此第 2.4 节中一切近似在这里都变成精确。配分函数化为使用同一熵 $h(m)$ 的一维积分 (2.25)，鞍点方程为

$$m = \tanh\big(\beta(m + B)\big), \tag{5.2}$$

模型在 $\beta_c = 1$ 具有图 4 的二级相变，并在磁场 B 中具有图 2 的一级相变，与第 2.5 节分析的完全一样。

平均场理论在此为何精确，值得用一种能直接推广到网络的形式说明。单个自旋感受到的场为 $-\partial E_N/\partial s_i = m + B$：自旋 i 不关心任何一个单独的其他自旋，只关心经验平均 m，即 “平均场”。经典论证有三个特征：

1. 每个自由度只通过一个平均量与其他自由度耦合。（这里由构造保证。）
2. 平均量几乎不涨落。如果自旋大致独立，中心极限定理使 m 的涨落为 $O(1/\sqrt{N})$；$N \to \infty$ 时，每个自旋看到一个确定性的有效场 $m + B$。
3. 平均量由自洽条件确定。场 $m + B$ 中的单自旋满足 $\mathbb{E}(s_i) = \tanh(\beta(m + B))$；由于 m 定义为平均自旋，一致性要求式 (5.2) 成立。

对于有限维晶格，每个自旋只有少数强耦合邻居，上述步骤 1–2 是近似。对于 $1/N$ 全连接模型，它们在 $N \to \infty$ 时变为精确：平均场是 N 个弱关联项的平均，大数定律使其涨落消失。我们将看到，平均场标度下的网络恰是这类模型。

习题 5.1（通过不动点迭代求解 Curie–Weiss 模型）。 分别取高于和低于 1 的 β 以及几个 B 值，通过不动点迭代 $m^{(k+1)} = \tanh(\beta(m^{(k)} + B))$ 数值求解式 (5.2)，观察迭代收敛。哪些不动点是稳定的？请记住这一迭代：下文我们会遇到它的无限维对应物。

5.1.2 平均场模型的一般形式

上面的讨论并不需要二值自旋。更抽象地，可以取 N 个“粒子” $\theta_i \in \mathbb{R}^p$，其广延能量具有形式

$$E_N(\theta) = \sum_{i=1}^{N} V(\theta_i) + \frac{1}{2N} \sum_{i,j=1}^{N} U(\theta_i, \theta_j), \tag{5.3}$$

其中 V 是单粒子势、U 是对称的两体相互作用，同样具有特征性的 $1/N$ 耦合。粒子 θ_i 受到的力为 $-\nabla_{\theta_i} E_N$。进一步地，对于阻力占主导的粒子（高黏性运动），零温动力学由熟悉的梯度下降方程支配：

$$\dot{\theta}_i = -\nabla_{\theta_i} E_N = -\nabla V(\theta_i) - \frac{1}{N} \sum_{j=1}^{N} \nabla_1 U(\theta_i, \theta_j), \tag{5.4}$$

其中 ∇_1 表示对 U 的第一个变量求导。再一次，每个粒子只感受到力的经验平均。

值得将这一观察组织成一种可原样用于网络的形式。定义经验测度

$$\rho_N := \frac{1}{N} \sum_{i=1}^{N} \delta(\theta - \theta_i), \tag{5.5}$$

这是 $\mathbb{R}^p$ 上记录 N 个粒子所在位置的概率测度。那么式 (5.4) 表示，每个粒子都沿着同一个有效单粒子势下降，这个势由当前所有粒子的位置共同塑造：

$$\dot{\theta}_i = -\nabla_\theta \Psi(\theta_i; \rho_N), \qquad \Psi(\theta; \rho) := V(\theta) + \int U(\theta, \theta')\, d\rho(\theta'). \tag{5.6}$$

粒子仅通过 ρ_N 耦合，这恰好对应于“每个自旋只感受到 m”。与前面相同的三步论证启发我们：当 $N \to \infty$ 时，经验测度变得确定且自洽。下一小节中我们将为网络仔细完成这一推导。

5.2 单隐藏层网络的平均场标度

回到第 3.5 和 4.3 节的单隐藏层网络 (4.26)，但现在前面的归一化因子用 $1/N$ 而非 $1/\sqrt{N}$，权重仍为 $O(1)$：

$$f_\theta(x) = \frac{1}{N} \sum_{i=1}^{N} c_i \phi(a_i \cdot x), \qquad c_i, a_{ij} \sim \mathcal{N}(0, 1), \tag{5.7}$$

其中 $c_i \in \mathbb{R}$、$a_i, x \in \mathbb{R}^d$（如式 (4.26)，第一层的 $1/\sqrt{d}$ 因子已吸收入 x）。与第 3–4 节的扇入归一化相比，平均场标度使输出额外减小 $1/\sqrt{N}$。函数类完全相同，只是其坐标改变了。然而梯度流在重参数化下并不不变：正如第 4.1.1 节和第 4.3 节的提示所强调的，梯度下降以参数空间上的欧几里得度规为前提，而坐标重标度会改变该度规。同一函数类的两种参数化可以（且在这里确实会）沿着完全不同的轨迹演化。

在平均场分析中，N 个粒子就是 N 个隐藏神经元，参数为

$$\theta_i = (c_i, a_i) \in \mathbb{R}^{d+1}, \qquad i = 1, \dots, N. \tag{5.8}$$

它们的取值编码在经验测度 (5.5) 中，网络 (5.7) 只通过 ρ_N 依赖其参数：

$$f_\theta(x) = \int c\, \phi(a \cdot x)\, d\rho_N(c, a) =: f_{\rho_N}(x). \tag{5.9}$$

我们把网络值 f_ρ 看作 ρ 的线性泛函。神经元被视为可交换粒子，而测度就是它们的状态。

5.2.1 初始化

初始化时，式 (5.7) 的求和项 $c_i\phi(a_i\cdot x)$ 独立同分布且均值为零（因为 c_i 与 a_i 独立且 $\mathbb{E}[c_i]=0$）。在 $1/N$ 前因子下，大数定律对每个固定 x 给出

$$f_{\theta_0}(x)=\underbrace{\mathbb{E}[c\,\phi(a\cdot x)]}_{=0}+O(1/\sqrt{N})\xrightarrow{N\to\infty}0. \tag{5.10}$$

与第 3.4 节对比：采用 $1/\sqrt{N}$ 归一化时，相同的和恰好处在其涨落尺度上，中心极限定理产生 $O(1)$ 的高斯过程；平均场标度则处在均值尺度上。网络从（基本上）零函数开始训练；这里谈不上随机函数先验，训练后网络的任何形态都是训练构建出来的，而非从初始化继承。

5.2.2 损失是平均场能量

如第 4 节所述，对数据 $(x^\mu,y^\mu)_{\mu=1}^n$ 使用 MSE 损失训练：

$$\mathcal{L}(\theta)=\frac{1}{2}\sum_{\mu=1}^{n}\big(f_\theta(x^\mu)-y^\mu\big)^2. \tag{5.11}$$

代入式 (5.7) 并展开平方，得到

$$\mathcal{L}(\theta)=\text{常数}+\frac{1}{N}\sum_{i=1}^{N}V(\theta_i)+\frac{1}{2N^2}\sum_{i,j=1}^{N}U(\theta_i,\theta_j), \tag{5.12}$$

$$V(\theta)=-\sum_{\mu=1}^{n}y^\mu c\,\phi(a\cdot x^\mu),\qquad U(\theta,\theta')=\sum_{\mu=1}^{n}c\,\phi(a\cdot x^\mu)c'\phi(a'\cdot x^\mu). \tag{5.13}$$

将式 (5.12) 与式 (5.3) 比较可见，除一个整体的 N 因子外，损失恰好是平均场能量。特别地，$E_N:=N\mathcal{L}$ 具有式 (5.3) 的标准归一化且是广延量，而损失本身可解释为每个神经元的强度能量。

我们还可以辨认两个势的物理角色！V 有利于神经元的输出函数 $c\,\phi(a\cdot\,\cdot)$ 与数据对齐，起外场 B 的作用；U 则是神经元对之间以数据为权重的相互作用，惩罚冗余特征，起自旋—自旋耦合的作用。

5.2.3 运动方程与平均场

由于在这种参数化中 $\partial f/\partial\theta_i=O(1/N)$，损失 $\mathcal{L}$ 的原始梯度为 $O(1/N)$，因此若固定学习率，梯度流在 $N\to\infty$ 时会冻结。于是必须提高学习率：

$$\eta=N\widetilde{\eta}, \tag{5.14}$$

其中 $\widetilde{\eta}$ 固定。（等价地，可以对广延能量 $E_N=N\mathcal{L}$ 运行普通梯度流。）这正是第 4.3 节规则的应用：下面式 (5.24) 将计算得到 NTK 为 $O(1/N)$，所以要保持 $\frac{d}{dt}f^\mu=-\eta\Theta^{\mu\nu}\Delta_\nu$ 为 $O(1)$，就需要 $\eta\propto N$。注意它与第 4.3 节的区别：那里 NTK 是 $O(1)$，学习率不需重标度；这里 NTK 缩小为 $1/N$，我们相应提高学习率。

也请回顾该节关于变量替换的提醒。平均场网络同样可写为没有前因子的形式 $f=\sum_i\widetilde{c}_i\phi(a_i\cdot x)$，其中 $\widetilde{c}_i=c_i/N\sim\mathcal{N}(0,1/N^2)$；但这时为得到相同动力学式 (5.15)，读出权重 $\widetilde{c}_i$ 需要学习率 $\widetilde{\eta}/N$，隐藏权重 a_i 则需要 $N\widetilde{\eta}$——每层一个学习率，二者相差 N^2 倍。将所有权重保持为 $O(1)$ 才能让单个 η 发挥作用，这也是第 3.2 节采用该约定的原因。

使用式 (5.14) 后，流 $\dot\theta = -\eta\nabla_\theta\mathcal{L}$ 对每个神经元变为

$$\dot c_i = -\widetilde\eta \sum_{\mu=1}^{n} \Delta^\mu \phi(a_i\cdot x^\mu), \qquad\qquad \dot a_i = -\widetilde\eta c_i \sum_{\mu=1}^{n} \Delta^\mu \phi'(a_i\cdot x^\mu) x^\mu, \tag{5.15}$$

其中 $\Delta^\mu = f_{\rho_N}(x^\mu) - y^\mu$ 是第 4.1 节的残差。等价地，采用势函数形式 (5.6)，

$$\begin{aligned} \dot\theta_i &= -\widetilde\eta \nabla_\theta \Psi(\theta_i;\rho_N), \\ \Psi(\theta;\rho) &= V(\theta) + \int U(\theta,\theta')\,d\rho(\theta') = \sum_{\mu=1}^{n} \Delta_\rho^\mu c\,\phi(a\cdot x^\mu), \end{aligned} \tag{5.16}$$

其中 $\Delta_\rho^\mu = f_\rho(x^\mu) - y^\mu$。

正如预期，神经元 i 的速度依赖它自己的状态 (c_i, a_i)，并且仅通过平均 $f_{\rho_N} = N^{-1}\sum_j c_j\phi(a_j\cdot\,\cdot)$，经由残差 Δ^μ 依赖所有其他神经元。此处网络函数 f 就是平均场！由此得到对应表：

Curie–Weiss 模型	平均场标度下的单隐藏层网络
自旋 $s_i \in \{\pm 1\}$	神经元 $\theta_i = (c_i, a_i) \in \mathbb{R}^{d+1}$
磁化强度 $m = N^{-1}\sum_j s_j$	网络函数 $f_\rho = N^{-1}\sum_j c_j\phi(a_j\cdot\,\cdot)$
外场 B	数据项 V（目标 y^μ）
成对耦合 $-N^{-1}s_is_j$	神经元相互作用 $N^{-1}U(\theta_i,\theta_j)$
有效场 $m + B$	残差 $\Delta_\rho^\mu = f_\rho(x^\mu) - y^\mu$
广延能量 E_N	$N\mathcal{L}$（损失为强度量）
零温动力学	梯度流
温度为 T 的 Langevin 动力学	有噪声训练，第 2.1 节
$m = \tanh(\beta(m+B))$	自洽 Gibbs 测度，下文式 (5.22)

习题 5.2（平均场方程的结构）。

(a) 推导式 (5.12)–(5.13) 和 (5.15)，并利用 U 的对称性检验式 (5.16) 能复现它们。

(b) 均衡性（*balancedness*）。对于 ReLU 等正齐次激活函数，$\phi'(z)z = \phi(z)$。证明在此情况下，式 (5.15) 沿流对每个神经元精确守恒 $c_i^2 - |a_i|^2$。因此给定神经元的两层始终耦合。（另一方面，不同神经元将彼此解耦，稍后会看到。）

(c) 注意，对于 MSE 损失，式 (5.15) 中的 $\dot c_i$ 不依赖 c_i（只依赖 a_i 和平均场）。f_ρ 关于 c 的线性在何处发挥作用？

5.2.4 从粒子到测度：连续性方程

现在分几个步骤取 $N\to\infty$ 极限。

步骤 1：将 N 个耦合常微分方程重写为经验测度的一个方程。 （这在有限 N 时仍然精确。）假设粒子以某个速度场确定性地运动，$\dot\theta_t = v_t(\theta_t)$，令 ρ_t 为其中一个粒子的分布。光滑测试函数 g 的期望满足

$$\frac{d}{dt}\int g\,d\rho_t = \frac{d}{dt}\mathbb{E}[g(\theta_t)] = \mathbb{E}[\nabla g(\theta_t)\cdot v_t(\theta_t)] = \int \nabla g\cdot v_t\,d\rho_t = -\int g\,\nabla\cdot(\rho_t v_t), \tag{5.17}$$

最后一步使用分部积分。由于 g 任意，

$$\partial_t \rho_t + \nabla\cdot(\rho_t v_t) = 0. \tag{5.18}$$

这称为连续性方程，它仅仅表达概率守恒。将其应用于我们的系统，速度 $v_t = -\widetilde{\eta}\nabla\Psi(\cdot;\rho_{N,t})$ 来自式 (5.16)，于是经验测度满足（以弱意义，因为它是 delta 函数之和）

$$\partial_t \rho_{N,t} = \widetilde{\eta}\nabla\cdot\left(\rho_{N,t}\nabla_\theta \Psi(\theta;\rho_{N,t})\right). \tag{5.19}$$

这里平均场的 $1/N$ 全连接耦合的一个重要结果是，式 (5.19) 是关于 ρ_N 的闭合方程。

步骤 2：极限。 在有限 N 时，$\rho_{N,t}$ 是随机原子测度。（“原子”指它是 delta 函数之和；随机性来自随机初始化。）若独立同分布初始化 $\theta_i \sim \rho_0$，当 $N\to\infty$ 时，大数定律提示——文献 [56, 19, 72, 81] 中的定理也证实——$\rho_{N,t}$ 弱收敛到 ρ_t，后者是确定性的光滑概率测度曲线，满足极限偏微分方程

$$\partial_t \rho_t = \widetilde{\eta}\nabla\cdot\left(\rho_t\nabla_\theta(V + U*\rho_t)\right), \qquad (U*\rho)(\theta) := \int U(\theta,\theta')\,d\rho(\theta'). \tag{5.20}$$

对任意固定时间区间，存在定量的 $O(1/\sqrt{N})$ 误差界。

5.2.5 McKean–Vlasov 方程与自洽性

在此情形下，与 Curie–Weiss 自洽条件 (5.2) 即 $m = \tanh(\beta(m+B))$ 类似的方程称为 McKean–Vlasov 方程。为了得到它，关注单个代表性神经元 θ_i。当 $N\to\infty$ 时，可以用系综平均代替其所受的力：

$$\dot{\bar\theta}_t = -\widetilde{\eta}\nabla_\theta\Psi(\bar\theta_t;\rho_t), \qquad \text{满足}\quad \rho_t = \mathrm{Law}(\bar\theta_t). \tag{5.21}$$

约束 $\rho_t = \mathrm{Law}(\bar\theta_t)$ 就是该方程的全部内容：粒子受一个由分布构造的场驱动，而该分布又是它自己的概率分布。（概率论研究者称式 (5.21) 为非线性 Markov 过程：非线性针对分布，而非针对 θ。）McKean–Vlasov 方程与连续性方程等价；式 (5.21) 的粒子轨迹是偏微分方程 (5.20) 的特征曲线。

我们说明几个结构性特征：

- *混沌传播。*神经元仅通过 ρ_N（等价地通过 f_{ρ_N}）相互作用，而这一量在 $N\to\infty$ 时变为确定性，因此它们渐近独立：任意固定的 k 个神经元收敛为式 (5.21) 的 k 个独立同分布副本，不同神经元之间的关联量级为 $O(1/N)$。因此，初始化时的独立性得以传播，而非退化 [86]。

- *梯度流结构。*定义 $N\to\infty$ 的损失为测度的泛函 $\mathcal{L}[\rho] = \frac{1}{2}\sum_\mu (f_\rho(x^\mu) - y^\mu)^2$。由于 f_ρ 关于 ρ 线性，该泛函关于 ρ 是凸的。这最终导出全局收敛定理。例如，文献 [19] 证明，对齐次激活函数（如 ReLU），只要训练确实收敛，它就收敛到凸泛函 $\mathcal{L}[\rho]$ 的一个全局极小值。

- *温度。*如果改用第 2.1 节式 (2.6) 的 Langevin 动力学，在温度 $T = \beta^{-1}$ 下训练，会得到一个满足下式的平稳分布 [56]：

  $$\rho_\infty(\theta) \propto e^{-\beta\Psi(\theta;\rho_\infty)}. \tag{5.22}$$

  这又是“$m = \tanh(\beta(m+B))$”自洽条件的另一版本，此时用于有噪训练。

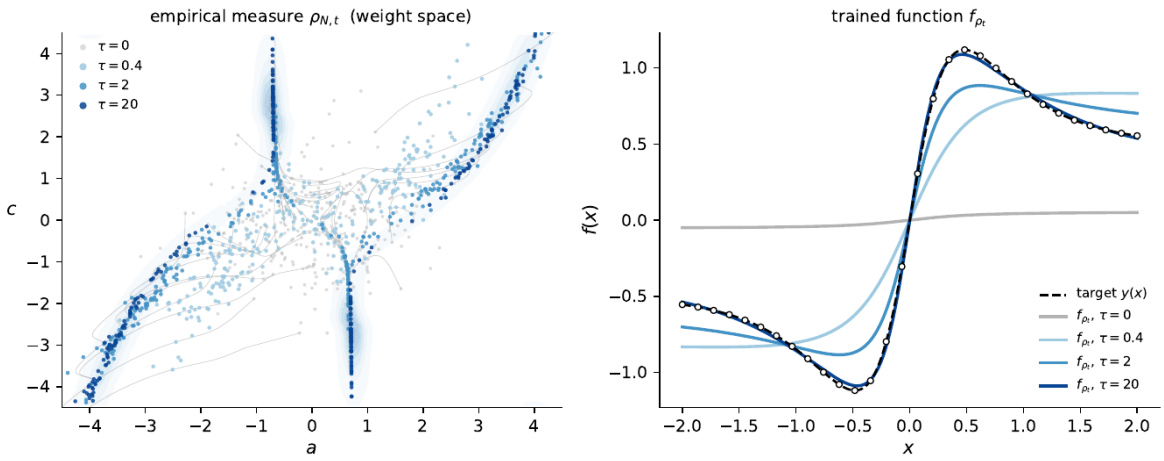


图 6: 一维例子的平均场训练：$f_\rho(x)=N^{-1}\sum_i c_i\tanh(a_ix)$，在双神经元教师 $y(x)=2\tanh(3x)-\frac{3}{2}\tanh(x)$ 的 $n=30$ 个样本上，按重标度梯度流 (5.15) 训练；$\tau=\widetilde{\eta}t$ 为重标度训练时间。左：$N=300$ 时 (a,c) 平面上的经验测度 $\rho_{N,t}$（点按时间着色，细灰线追踪其中 40 条粒子轨迹），叠加 $N=30000$ 运行在 $\tau=20$ 时的密度（阴影等高线），作为极限测度 ρ_t 的替代。单个神经元移动 $O(1)$ 距离，测度凝聚到实现教师的配置所构成的一维细丝上。（点对称 $(a,c)\mapsto(-a,-c)$ 反映 tanh 的奇性。）右：平均场本身 $f_{\rho_t}(x)$ 收敛到目标（虚线；圆圈标记训练数据）。图中文字对照：左图横轴为 a、纵轴为 c，右图横轴为 x、纵轴为 $f(x)$；两图均比较 $\tau=0,0.4,2,20$，“empirical measure (weight space)” 为权重空间中的经验测度，“trained function” 为训练中的函数，“target” 为目标。

实际上如何求解自洽系统 (5.21)？方法与求解式 (5.2)（习题 5.1）相同：冻结一个猜测的环境 ρ_t，求解现在成为普通微分方程的问题，计算解的分布，再把它反馈回去并迭代。短时间区间内该映射是压缩映射，这也是存在性、唯一性与混沌传播一并得到证明的方式 [86]。另一方法是在网格上求解偏微分方程 (5.20)，它（仅）对小 d 可行。

图 6 中我们则直接通过训练一个 $d=1$ 网络求解系统。左图每个点是一个神经元。训练是神经元云的流动，云凝聚到权重空间中实现目标的低维结构上，即学习其特征。习题 5.3 复现该图，并把它与惰性网络中冻结的云并列比较。

习题 5.3（数值实验：平均场网络）。 （⋆）继续习题 4.4 的实验：使用相同数据、相同教师 $y(x)=2\tanh(3x)-\frac{3}{2}\tanh(x)$ 和相同学生式 (4.40)，但现在使用平均场指数 $\gamma=1$ 和重标度更新 (5.15)：

$$
\begin{aligned}
c_i &\mathrel{-}= \Delta\tau\sum_{\mu}\Delta^{\mu}\tanh(a_ix^{\mu}),\\
a_i &\mathrel{-}= \Delta\tau\, c_i\sum_{\mu}\Delta^{\mu}\big(1-\tanh^2(a_ix^{\mu})\big)x^{\mu},
\end{aligned}
\tag{5.23}
$$

取 $\Delta\tau=5\times10^{-4}$，训练 4×10^4 步，使重标度时间 $\tau=\widetilde{\eta}t$ 到达 20。注意这些更新中没有 $1/N$：这正是所需的 $O(N)$ 学习率 (5.14)，已包含在内（$\eta=N\Delta\tau$）。用 $\gamma=1$ 监控式 (4.41) 的 NTK。

(a) 它能拟合。训练并检查损失是否变小，尽管按重标度时间计算它比惰性训练慢。

(b) *初始化*。对几个 N 值，使用约 200 个随机种子，绘制 $x=1$ 时 $f_0(x)$ 的直方图：分布收缩到 0，宽度约为 $1/\sqrt{N}$。检验这一标度。

(c) *核移动*。对 $N\in\{30,100,300,1000\}$ 记录 $\|\Theta_{\text{end}}-\Theta_0\|/\|\Theta_0\|$，并与习题 4.4(c) 的惰性曲线画在一起：一张图、两条曲线，完整呈现两种情况的区别。

(d) *观察粒子*。对两次训练，在 $\tau\approx 0, 0.4, 2, 20$ 时画出神经元云 (a_i, c_i) 的散点图。惰性情形：云是静止的（每个权重移动 $O(1/\sqrt{N})$）。平均场情形：云发生输运并凝聚到实现教师的配置所构成的细丝上，如图 6。取 $N=3000$ 重复：图样相同，因为你观察的是确定性极限测度。

(e) *进一步探索*。起始教师本身是一个双神经元 tanh 网络，因此学生的特征可以与教师完全对齐。这是特征学习还是特征复制？尝试模型类之外的教师，并观察神经元云的变化：$y(x)=\sin(2x)$；$y(x)=|x|-1$；对 tanh 教师使用 ReLU 学生（或反之）；或者转向 $d=2$，取 $y(x)=\tanh(x_1+x_2)$ 并绘制方向 $a_i/|a_i|$ 的云。哪些 (c)–(d) 中的现象是普适的，哪些是对齐情形特有的？

5.3 NTK 不再是常数：特征学习

第 4.3 节表明，扇入归一化下 $N\to\infty$ 时 NTK 冻结；第 4.2 节将特征学习定义为 NTK 在训练期间的变化。让我们用平均场标度重新计算。由式 (5.7)，$\partial f/\partial c_i = N^{-1}\phi(a_i\cdot x)$ 且 $\partial f/\partial a_i = N^{-1}c_i\phi'(a_i\cdot x)x$，所以第 4.1 节的 NTK 为

$$\Theta(x,x') = \frac{1}{N^2}\sum_{i=1}^{N} k_{\theta_i}(x,x') = \frac{1}{N}\int k_\theta(x,x')\,d\rho_N(\theta), \tag{5.24}$$

$$k_\theta(x,x') := \phi(a\cdot x)\phi(a\cdot x') + c^2\phi'(a\cdot x)\phi'(a\cdot x')\,x\cdot x'. \tag{5.25}$$

因此 $\Theta=O(1/N)$，重现了之前梯度很小的观察，这也是重标度式 (5.14) 的原因。第 4.3 节的估计还解释了为什么核现在可以自由移动。Hessian 块 (4.27) 带有 $1/N$ 而非 $1/\sqrt{N}$，所以 $\|\nabla_\theta^2 f\| = O(1/N)$；但学习率为 $\eta=N\widetilde{\eta}$，因此界 (4.25) 对相对漂移给出 $\|\dot\Theta\|/\|\Theta\| \lesssim \eta\|\nabla_\theta^2 f\||\Delta| = O(1)$。该界不再迫使核冻结，而运动方程 (5.15) 将表明它确实会移动。当 $N\to\infty$ 时，有意义的对象是 $N\Theta=\int k_\theta\,d\rho_N$，函数空间动力学 (4.10) 现在变成具有含时核的核梯度流：

$$\frac{d}{dt}f^\mu = -\widetilde{\eta}\big(N\Theta^\mu{}_\nu\big)_{\rho_t}\Delta^\nu, \qquad\qquad (N\Theta)_{\rho_t} = \int k_\theta\,d\rho_t. \tag{5.26}$$

初始化时大数定律使 $N\Theta\to\mathbb{E}_{\rho_0}[k_\theta]$，这是确定性核——与扇入归一化中式 (4.24) 的极限核相同。两个极限从同一处出发。

然而，训练期间它们分道扬镳。第 4.3 节中，每个参数仅移动 $O(1/\sqrt{N})$，所以 ρ_N 始终在距 ρ_0 的 $O(1/\sqrt{N})$ 范围内，核因式 (4.31) 被固定。而这里运动方程 (5.15) 使每个粒子移动 $O(1)$ 距离。（每个神经元只有 $O(1/N)$ 的影响，因此拟合数据迫使平均神经元移动 $O(1)$ 距离。）故 ρ_t 发生宏观输运，且由式 (5.26)，核也随之发生 $O(1)$ 变化。

5.4 标度旋钮与最大更新参数化

考察一整个单参数标度族非常有启发性：其两个端点分别是扇入 / NTK 标度和平均场标度。这个族可以通过如下前因子编码：

$$f_\theta(x) = \frac{1}{N^\gamma}\sum_{i=1}^{N} c_i\phi(a_i \cdot x), \qquad \gamma \in [\tfrac{1}{2}, 1], \tag{5.27}$$

其中 $c_i, a_{ij} \sim \mathcal{N}(0,1)$。对每个 γ，当 $N \to \infty$ 时必须同时将学习率标度为 $\eta = N^{2\gamma-1}\widetilde{\eta}$，使函数空间动力学保持 $O(1)$（可从 $\Theta \sim N^{1-2\gamma}$ 推出）。重复以上估计得到（见习题 5.4）：

	初始化的 f_{θ_0}	每个神经元的运动	极限
$\gamma = \frac{1}{2}$	$O(1)$（GP，CLT）	$O(N^{-1/2})$	惰性：第 3、4 节
$\frac{1}{2} < \gamma < 1$	$O(N^{1/2-\gamma}) \to 0$	$O(N^{\gamma-1}) \to 0$	惰性（冻结核，零初始化）
$\gamma = 1$	$O(N^{-1/2}) \to 0$	$O(1)$	平均场：本节

值得注意的是，每个中间值 γ 都坍缩到核极限：初始化 GP 被标度掉，但神经元的位移仍趋于零，因此训练再次在一个（适当重标度的）冻结核中线性化 [20, 56]。平均场 $\gamma = 1$ 是这个族中唯一同时具有良好定义的极限与 $O(1)$ 特征移动的标度；它是在不发散的前提下能够取得的“最大更新”。这种唯一性可从单隐藏层推广到任意深度（此时一致性迫使学习率和初始化按层采用不同标度），在 Yang 和 Hu 的张量程序系列工作中称为最大更新参数化 μP[96]。特别地，对 $L = 1$，平均场标度就是 μP。

习题 5.4（沿标度旋钮比较惰性与丰富）。 对于式 (5.27) 的族：

(a) 证明 $\Theta = O(N^{1-2\gamma})$，从而 $\eta = N^{2\gamma-1}\widetilde{\eta}$ 是正确的联合标度；

(b) 证明初始化输出为 $O(N^{1/2-\gamma})$，每个神经元的速度为 $O(N^{\gamma-1})$；

(c) 由此得出：在任意固定训练时间区间上，（归一化）核漂移为 $O(N^{\gamma-1})$，对每个 $\gamma < 1$ 均趋于零；

(d) 将 $\gamma = \frac{1}{2}$ 与第 4.3 节的界联系起来。选做：联系文献 [20] 的输出尺度参数 α，该文中给任意模型乘上 $\alpha \to \infty$ 会产生惰性训练。

5.5 这个框架有什么用途？

没有人会为真实网络求解 McKean–Vlasov 偏微分方程 (5.20)！但它确实带来三类实际收益：标度方案、机制识别，以及供后续理论使用的约化描述。

超参数迁移（μP）是一个关键应用。平均场分析从根本上说，是研究初始化和学习率的何种联合标度能够在 $N \to \infty$ 时保持训练动力学非退化并持续学习特征的理论。它对深网络的推广 [96] 把这一点变成工程方案 μTransfer[97]：对网络作参数化，使其无限宽极限为特征学习极限；这样最优超参数近似不依赖宽度，可以在小型代理模型上调参，再将设置迁移到大模型。在最初的展示中，这种方法以预训练费用的几个百分点重新调优了 GPT-3 6.7B，且优于已发表的模型；这种参数化的变体如今已成为大规模训练中的标准做法。

第 5.4 节的旋钮还允许我们在真实架构上于不同区域之间插值，衡量特征学习究竟在何处产生收益。核区域行为在小数据集上往往有竞争力，而在 CIFAR 规模的图像任务中，训练后的网

络大幅胜过自身冻结的 NTK[30]。这类思想导出的诊断方法（如训练中核的距离 / 对齐度，以及静默对齐效应 [4]）如今是常规工具，可用于追问：“我的网络是否真的在学习特征，还是只是在做核回归?”

这里的平均场极限固定数据并令 $N \to \infty$，遗憾的是，这还不能构成真实数据 / 宽度比例下泛化的定量理论。第 6 节的动力学平均场理论 [12] 会在一定程度上改进这一点；它是当前分析的场论式细化，其扩展确实重现了计算最优的神经标度律，尤其是在大数据集下 [9]。

5.6 作为惰性到丰富转变的顿悟：阅读习题

本节最后安排两篇引导式阅读，将前面介绍的不同概念应用于学习中最有趣、最基本的现象之一：顿悟（grokking）[67]。顿悟是指以下行为：在算法数据集上训练一个小网络——典型例子是模 P 加法，以数对 (n, m) 为输入、$(n+m) \bmod P$ 为标签，只展示全部 P^2 个事实中的一部分。网络很快达到完美训练准确率，而测试准确率仍处于随机水平：它只是记住了数据。然而，在训练继续多个数量级、训练损失趋平很久之后，测试准确率突然跃升到接近 100%。这种延迟而突然出现的泛化及涌现能力需要机制解释。

理论提出了至少两种定量解释，本小节与下一小节分别引导阅读其中一种：Kumar、Bordelon、Gershman 和 Pehlevan 的动力学视角 [49]（本小节），将顿悟视作从惰性到丰富动力学的延迟转变；以及 Rubin、Seroussi 和 Ringel 的平衡态视角 [73]（第 5.7 节），将顿悟视作伴随亚稳态滞后的一级相变。两份引导阅读结构平行，使用的讲义工具大体不同。动力学版本要求熟悉第 4 节和第 5.4 节；贝叶斯版本更为密集，将标度分析与平均场近似结合。

Kumar、Bordelon、Gershman 和 Pehlevan 的工作 [49] 完全不涉及统计力学系综，只有随时间展开的梯度下降，以及第 5.4 节的惰性 / 丰富旋钮。论文认为，网络发生顿悟的过程是：首先通过廉价而快速的通道拟合训练数据，即使用初始化时冻结 NTK 的核回归；由于初始核与任务不对齐，这种惰性拟合记忆数据而不泛化。接着，在由网络惰性程度控制的较慢时间尺度上，特征终于发生移动（核如第 5.3 节所述发生旋转），找到一个能够泛化的解，测试损失在训练损失下降很久之后才下降。这项工作有两个精彩之处：其最清楚的例子在零权重衰减的普通梯度下降下发生顿悟；并且参数范数在顿悟期间增大。两点都直接反驳了早期建立在权重衰减和范数缩小之上的顿悟解释。

论文几乎完全使用本讲义已经建立的语言（第 4、5 节），因此下面的术语对照框较短。请阅读引言、两层多项式回归模型和实验（模运算、MNIST、单层 Transformer）；首次阅读时跳过动力学平均场渐近分析——那部分工具属于第 6 节。然后完成习题 5.5。

说明：文献术语对照。 以下将 [49] 中的一些术语翻译为本讲义的语言：

- *惰性 / 线性化动力学*：第 4.3 节的区域。网络只在初始梯度张成的仿射子空间 (4.1) 中移动，所以训练是使用冻结初始 NTK 的核回归（第 4.1、4.6 节）。
- *惰性参数 α*：网络输出上的总体乘子，$f \mapsto \alpha f$，同时对损失和学习率作联合标度。它是第 5.4 节 γ 旋钮的连续版本，采用 [20] 提出的形式：$\alpha \to \infty$ 完全惰性，α 小则为丰富区域。
- *核与任务的（不）对齐*：第 4.2 节的语言，即目标在初始 NTK 的前几个本征模态上有多少分量。不对齐意味着目标权重位于小本征值模态，而第 4.6 节的模态滤波公式表明，这些模态无法从可用数据中学到。

- *充分统计量*：权重的少量标量函数，其闭合动力学决定测试损失；它们是第 2 节序参量的动力学对应物。

习题 5.5（作为惰性到丰富转变的顿悟）。 按上文要求阅读 [49]，回答以下问题，并指出论文中各答案所在的位置。（(a)–(e) 在另一份引导阅读的习题 5.6 中均有精确对应；(f) 是共同的比较问题。）

(a) 分析处于什么区域，由哪个旋钮控制？这里没有热力学极限，也没有平衡系综，那么其他地方由“标度极限”扮演的角色在这里由什么承担？惰性参数 α 如何实现，它与第 5.4 节的 γ 旋钮有何关系？第 5.2 节的标度方案有两个部分：输出尺度和学习率尺度。这里是哪一部分在发挥作用？（另一份引导阅读涉及相反的部分，参见习题 5.6(a)。）

(b) 什么量起序参量的作用？哪个量区分记忆态和泛化态，如何在真实训练中测量？与另一份引导阅读中起此作用的 Fourier 重叠 $\Phi(w)$（习题 5.6(b)）比较：两个量共享哪些信息？

(c) *必要条件*。论文指出发生顿悟的三个条件。找到它们，并分别翻译为本讲义的语言（第 4.3、4.6 和 5.4 节）。

(d) *调节了哪个参数*？什么让顿悟更加显著，什么让它彻底消失？理论在 $\alpha \to \infty$ 和 α 很小这两个极端分别预测什么？与习题 5.6(d) 的控制参数比较。

(e) *延迟从何而来*？两种理论都必须解释训练损失下降与测试损失突变之间的时间差。这里没有亚稳性、也没有噪声——那么单个确定性流中是什么产生了两个分离很远的时间尺度？每种理论需要什么才能产生延迟（噪声？权重衰减？两者都不需要？）论文中零权重衰减、范数增长的实验对早期顿悟解释有何影响？

(f) *综合*。第 5.7 节的平衡态机制与本节的动力学机制是彼此不相容，还是同一现象的两个角落？设计至少一个实验，使其结果偏向其中一种解释；例如考虑固定超参数时顿悟延迟如何依赖训练噪声，或每种机制下延迟如何随随机种子涨落。

5.7 贝叶斯顿悟：一级相变（另一份阅读）

另一份引导阅读采用相反的出发点。至此，延迟而突发的泛化也应当唤起第 2.5 节的一种直觉：自由能中相互竞争的分支、一级相变和亚稳态滞后，恰如第 2.6 节对伊辛感知机的剖析。论文 [73] 使这种直觉精确化，也是本讲义合适的收尾：它把我们开发的几乎所有工具汇集到一个真实（尽管很小）的深度学习现象中：有噪训练的 Gibbs 后验（第 2.1 节）、GP 核与核回归（第 3.3 和 4.6 节）、平均场标度与自洽性（本节）以及一级相变的结构（第 2.5 节）。然而，这确实是一篇信息密集的论文，使用“自适应核”学派 [76] 特有的术语。因此，本小节按第 1 节的方式组织成阅读习题：目标是识别结构，而不是验证计算。请阅读论文的引言、设定及模运算结果（首次阅读不要读附录），然后完成习题 5.6。

热身。 在进入统计力学之前，具体了解网络试图变成什么会有所帮助。Gromov[34] 写出一个二层二次激活网络求解模加法的精确权重：第一层权重是 $\mathbb{Z}_P$ 上的平面波——在不同频率 k 处具有分量 $\cos(2\pi kn/P)$ 和 $\sin(2\pi kn/P)$——二次激活的积化和差恒等式把它们转化为所需的 $(n+$

$m) \bmod P$ 的函数。略读 [34]，直到相信这一点即可。由此可见，“第一层权重的 Fourier 系数” 成为衡量网络实际学到了多少结构的自然坐标系。

说明：论文语言对照。 以下将论文术语对应到本讲义语言：

- *平衡态的 Langevin 训练*：与第 2.1 节完全相同：带权重衰减的有噪梯度下降；长时间下得到 Gibbs 后验；权重衰减 γ 决定高斯先验，噪声水平决定温度。
- *（自适应）核*：第 3.3 节的 GP 核，但在后验而非先验中自洽计算：核决定隐藏权重的后验，后验又决定核。这是自洽 Gibbs 测度 (5.22) 的有限温度对应物。
- *等效核（EK）近似*：第 4.6 节的稠密数据近似，将对训练点的求和替换为对输入分布的积分。它与退火近似有亲缘关系。
- *平均场标度*：读出权重的初始方差为 σ_a^2/N，且 $N \to \infty$ 时 $\sigma_a^2 \to 0$；它与式 (5.7) 中 $1/N$ 的关系是习题 5.6(a) 的内容。
- *GFL（高斯特征学习）相*：无序相；单神经元后验为高斯分布，且与教师结构的重叠以零为中心，核只发生微扰性适应。
- *混合相*：有限比例的神经元移动到非零重叠（此处即任务的 Fourier 模态），而其余仍为高斯分布；这种共存是一级相变的信号，参见第 2.6 节。

习题 5.6（作为一级相变的顿悟）。 按上文要求阅读 [73] 并回答下列问题，标明论文中每个答案所在的位置。（(a)–(e) 在另一份引导阅读的习题 5.5 中有精确对应；后者的 (f) 是共同比较问题。）

(a) 采用了什么标度极限？找出固定输出层权重衰减的地方以及 “平均场标度” 一词。论文中的标度与参数化 (5.7) 及第 5.4 节的 γ 旋钮有何关系？注意——这比看起来微妙：平衡态（贝叶斯）框架中没有学习率，因此第 5.2 节标度方案的哪一部分保留下来，以何种组合出现？

(b) 模加法任务的序参量是什么？转变两侧单个神经元输入权重的后验分布分别是什么样？有序侧与第 5.2 节的哪张图相似？

(c) 主要计算技术是什么？列出它们，并分别对应到本讲义中其前身所在的章节。

(d) 在论文的相图中，调节哪个参数以穿过相变？

(e) 时间到哪里去了？顿悟是关于训练时间的陈述，但论文计算的是静态平衡系综。平衡自由能中的一级相变如何在训练过程中产生延迟而突发的泛化？与第 2.6 节伊辛感知机的亚稳性讨论逐条比较。

6 非平衡物理、MSRJD 与 DMFT

至今为止，我们的统计力学工具箱都是平衡态的：Gibbs 测度、配分函数和自由能（第 2 节），以及训练简化为核回归（第 4 节）或确定性测度流（第 5 节）的极限。本节介绍直接面对学习动力

学的形式。其策略借自非平衡统计物理：先将随机动力学本身写成路径积分，即 Martin–Siggia–Rose–Janssen–De Dominicis（MSRJD）构造；再对随机性取平均，包括噪声、初始化，以及关键的训练数据，后者恰如第 2.3 节被视作淬火无序；最后导出一组少数双时间序参量的闭合自洽方程，这些序参量是关联函数 $C(t,t')$ 和响应函数 $R(t,t')$。结果称为动力学平均场理论（DMFT），是本讲义“平均场”的第三种、也是最后一种形式：第 2 节的静态理论自洽决定标量，第 5 节的 McKean–Vlasov 极限决定一个测度，而 DMFT 决定完整的双时间函数。

本节的成果包括一个完整推导的应用——线性回归中作为动力学相变的双下降（第 6.2 节）——以及现代深度学习 DMFT 研究计划的引导介绍（第 6.3 节），其标度律应用将在第 7 节结束本讲义。全文遵循 Altland 和 Simons[2] 的精神，该书用凝聚态语言阐释这一形式，在细节和直觉间取得良好平衡；我们还大量借鉴了为神经科学工作者写的两篇教学综述 [22, 85]。

6.1 从随机动力学到路径积分：MSRJD 形式

当我们用模型描述具有涨落的系统，或如第 2.1 节的 Langevin 动力学那样有意向确定性模型加入噪声时，微分方程会变为随机的，求解难度随之陡增。例如，一阶随机微分方程具有形式

$$\frac{dx}{dt} = f(x) + \xi, \tag{6.1}$$

其中 $\xi(t)$ 是（高斯）白噪声过程——加性噪声 $\xi = \xi(t)$，不同于乘性噪声 $\xi = \xi(x,t)$——而 $x = x(t)$ 现在是一条随机轨迹。噪声完全由一、二阶矩确定：

$$\langle \xi(t) \rangle_\xi = 0, \qquad \langle \xi(t)\xi(t') \rangle_\xi = D\delta(t-t'), \tag{6.2}$$

其中期望对噪声系综取。[12]求得 $x(t)$ 的概率分布随时间演化的闭式解通常颇有挑战。可以使用传统途径——Langevin 与 Fokker–Planck 描述——研究这种演化，标准参考文献为 Risken[70]、Gardiner[29] 和 van Kampen[91]。这里关注的对象则是 $x(t)$ 的矩和概率密度函数 $p(x,t)$。统计物理中开发的路径积分方法（尤其是用于微扰量子场论与经典非平衡系统的方法）提供了计算这些统计对象的途径。路径积分或泛函积分方法便于做微扰计算（用一个小参数围绕精确可解理论展开），但当不存在小参数或展开失效时（这种情况很常见），它也允许引入重整化群等其他工具或显式非微扰方法。

MSRJD 形式的概念步骤很简短，值得在推导之前先理解：

- 写出离散随机微分方程，并固定一个保证因果性的约定（Itô）；
- 用施加更新规则的 delta 函数表示相邻时间步之间的转移概率；
- 将无穷小时间步的乘积组合成路径积分；
- 将每个 delta 函数写成 Fourier 表示，引入辅助响应场；
- 对噪声取平均，然后加入源并求导以提取统计量。

历史上 Onsager 和 Machlup[63] 的方法是这一类 “Hamiltonian” 方法的 “Lagrangian” 版本；二者由 Legendre 变换联系，等价地，也可通过对辅助场积分联系。这个辅助场恰当地被称为响应

[12]记号方面，η 和 ζ 也常用来表示噪声；我们分别用 δ_{ij} 和 $\delta(t-t')$ 区分离散与连续的 delta 函数。

场：正如下面将看到的，它的关联函数计算系统对外部扰动的响应，它正是非平衡形式中真正新的成分。

现在快速但完整地推导。标准的第一步是将连续方程的时间离散化，或直接从离散更新规则出发。按这一离散化，$x(t) \to x_i$，其中 $i = 1, \dots, N$，使得

$$x_i = x_{i-1} + \Delta t\big(f(x_{i-1}) + \xi_{i-1}\big), \tag{6.3}$$

Δt 是时间间隔。可以重新排列使右侧为零，将步与步之间的转移概率写成 delta 函数，再用这些函数的乘积表示一个轨迹解。将随机微分方程的解记为 $x[\xi]$，可观测量 $A[x]$ 的期望形式上为

$$\langle A[x]\rangle_\xi = \int \mathcal{D}x\, A[x]\langle\delta(x - x[\xi])\rangle_\xi = \int \mathcal{D}x\, A[x] \left|\frac{\delta X}{\delta x}\right| \delta(X). \tag{6.4}$$

我们使用简写 $X_i \equiv x_i - x_{i-1} - \Delta t[f(x_{i-1}) + \xi_{i-1}]$ 表示每一步施加的约束。这里的测度是典型泛函路径积分测度 $\mathcal{D}x = \prod_i dx_i$，$\delta(x - x[\xi])$ 也类似地按各步分解。特别地，我们选取了一阶有限差分，并约定在前一时间步计算噪声，称为 Itô 离散化或 Itô 约定。许多常见过程明显采用 Itô 形式，例如 SGD：一个批次抽取的噪声不会影响该次迭代的权重。也有其他约定，最常见的替代方案是 Stratonovich（更像中点规则）；但 Itô 具有单位（保持体积的）泛函行列式，其他方案需要谨慎处理，避免行列式带来的异常项。在本例中矩阵是对角元为 1 的三角矩阵。代入 X 的定义，

$$\langle A[x]\rangle_\xi = \int \mathcal{D}x\, A[x]\, \big\langle \delta\big(\partial_t x - f(x) - \xi\big)\big\rangle_\xi\,. \tag{6.5}$$

最后，可以使用 delta 函数的 Fourier 表示，引入辅助变量 $\widetilde{x}$；在连续极限中，

$$\langle A[x]\rangle_\xi = \int \mathcal{D}x\, \mathcal{D}\widetilde{x}\, A[x] e^{i\int dt\, \widetilde{x}(\partial_t x - f(x) - \xi)}. \tag{6.6}$$

译注：式 (6.4) 最右侧与式 (6.6) 按原文保留，虽然右侧仍含随机噪声而没有显式的噪声平均；下一步计算使用该平均，表达式需结合此点理解。

最后一步得到关键结果：噪声现在在线性地出现在指数中，所以可以精确完成对 ξ 的高斯平均，$\langle e^{-i\int dt\, \widetilde{x}\xi}\rangle_\xi = e^{-\frac{D}{2}\int dt\, \widetilde{x}^2}$，从而得到 MSRJD 泛函积分：

$$\langle A[x]\rangle = \int \mathcal{D}x\, \mathcal{D}\widetilde{x}\, A[x] e^{-S[x,\widetilde{x}]}, \qquad S[x,\widetilde{x}] = \int dt \left[-i\widetilde{x}\big(\partial_t x - f(x)\big) + \frac{D}{2}\widetilde{x}^2\right]. \tag{6.7}$$

下面有四条结构性说明，稍后各有实际用途：

- *配分函数等于一。*令 $A = 1$，积分只是对归一化概率做 $\int \mathcal{D}x$：无源时 $Z_{\mathrm{dyn}} = 1$。与平衡态不同，所有物理信息都存在于关联函数中；对 x 和 $\widetilde{x}$ 同时耦合源并求导即可得到关联函数，比较第 6.2 节从 $Z_{\mathrm{dyn}} = 1$ 出发的做法。

- *响应场名副其实。*扰动漂移项 $f \to f + h(t)$，使作用量变化 $i\int \widetilde{x} h$，所以

$$R(t,t') := \left.\frac{\delta\langle x(t)\rangle}{\delta h(t')}\right|_{h=0} = \langle x(t) i\widetilde{x}(t')\rangle. \tag{6.8}$$

  $\widetilde{x}$ 的关联函数计算对扰动的响应。因果性已内置：$t < t'$ 时 $R(t,t') = 0$（Itô 离散化保证这一点，同时保证 $\langle\widetilde{x}\widetilde{x}\rangle = 0$）。[13]

[13]译注：上述公式按原文保留。按式 (6.7) 的 e^{-S} 及 $f \to f+h$ 约定直接求导，响应关联式的符号似应为 $-\langle x(t)i\widetilde{x}(t')\rangle$；需进一步核查 Fourier 与响应场约定。

- 双时间可观测量。该形式的自然对象是关联函数 $C(t,t') = \langle x(t)x(t')\rangle$ 和响应 $R(t,t')$。在平衡态它们不是独立的：涨落—耗散定理（FDT）将它们联系起来，$t > t'$ 时 $TR(t,t') = -\partial_{t'}C(t,t')$，在我们的归一化中 $T = D/2$[48, 47]。因此实测的 FDT 违背是系统真正处于非平衡态的标准诊断，也是在第 6.2 节发挥很大作用的警示灯。[14]

- *Onsager–Machlup*。作用量 (6.7) 对 $\widetilde{x}$ 为二次型，因此可精确对响应场积分，得到轨迹概率 $P[x] \propto e^{-\frac{1}{2D}\int dt\,(\partial_t x - f(x))^2}$：这就是上面所说的 Lagrangian 形式，其中最可能的路径使经典作用量取驻值。

习题 6.1（Ornstein–Uhlenbeck 过程与 FDT）。

(a) 补全导出式 (6.7) 的噪声平均步骤。

(b) 对线性漂移 $f(x) = -kx$（Ornstein–Uhlenbeck 过程），通过对二次作用量做 Fourier 变换或直接求解随机微分方程，计算平稳关联与响应函数：$C(\tau) = \frac{D}{2k}e^{-k|\tau|}$，$R(\tau) = \theta(\tau)e^{-k\tau}$。

(c) 对 $\tau > 0$，取 $T = D/2$，验证涨落—耗散定理 $TR(\tau) = -\partial_\tau C(\tau)$。

(d) 根据离散时间构造，解释为何 $\langle\widetilde{x}(t)\widetilde{x}(t')\rangle = 0$，以及 R 为什么满足因果性。

6.2 作为动力学相变的双下降

作为该形式的完整应用，我们介绍 Li 和 Goldenfeld 的近期工作 [53]。该工作使用动力学平均场理论分析双下降现象，并将其归类为动力学相变，全部工作都在最简单的设定内完成：线性回归的教师—学生模型。即使这个非常简单的模型也需要很长的计算，但尽管有这些额外工作，论文仍然相当易读。主要结果是：在欠参数化区域，优化过程是遍历的，并弛豫到有限误差的解；而过参数化区域是具有真正非平衡动力学的非遍历相——最初的记忆阶段留下对初始条件的持久记忆，并将动力学限制在初始化附近的子空间。诊断量是第 6.1 节的响应函数 $R(t,t')$，即时间 t' 的扰动如何影响时间 t 的模型状态；同一对象在量子力学、信号分析和信息论中作为 Green 函数出现。欠参数化区域中响应函数衰减，记忆消失；过参数化区域中它饱和到有限值，留下对初始化的持久记忆。与之相符，前一相遵守涨落—耗散定理 [48, 47, 33]，而后一相中 FDT 破缺——这是第 6.1 节提到的系统离开平衡态的标准警示灯。这里的模型非常简单，作者提出此类框架可能推广到不同架构，并根据任务变化产生不同普适类；他们提出带乘性（状态依赖）噪声的随机特征模型作为扩展，希望最终得到解释神经网络中相变的重整化群框架。

6.2.1 模型定义与形式

记号。 我们将论文转写到本讲义的约定中：P 个可训练参数、n 个训练样本、学习率 η、教师权重 w^*、学生权重 $\widehat{w}$（及响应场 $\widetilde{w}$），并以过参数化比

$$\nu := P/n \tag{6.9}$$

作为控制参数——它是第 2 节负载 $\alpha = n/N$ 的倒数，因此过参数化相为 $\nu > 1$。对于对照原论文的读者，记号对应如下：

[14] 译注：此式按原文保留。对习题 6.1 的平稳 Ornstein–Uhlenbeck 例子，令 $\tau = t - t' > 0$，则 $-\partial_\tau C = +\partial_{t'}C$；因此原文此处与该例使用的符号不一致，需核查时间变量约定。

本讲义	Li–Goldenfeld[53]
P（参数数）	d
n（样本数）	N
$\nu = P/n$	$\alpha = d/N$
$w^*, \widehat{w}, \widetilde{w}$	$\beta, \widehat{\beta}, \widetilde{\beta}$
η（学习率）	ζ

批次纳入概率 γ、岭参数 λ 以及标签噪声方差 D 与论文相同。

具体而言，学生与教师具有相同架构：

$$y^{\mu} = \frac{1}{\sqrt{P}} \sum_{i=1}^{P} w_i^* x_i^{\mu} + \epsilon^{\mu}, \tag{6.10}$$

其中 P 是模型参数数目，$\mu = 1, \ldots, n$ 为输入 x^{μ} 的数据集索引，w_i^* 为教师权重，ϵ^{μ} 是标签噪声。热力学极限取 $n \to \infty$、$P \to \infty$，同时固定过参数化比 $\nu = P/n$——论文中的**复杂度参数**。三个主要区域定义为欠参数化 $\nu < 1$、临界附近 $\nu \approx 1$ 和过参数化 $\nu > 1$。其优化过程为 SGD，同时具有由 λ 控制的正则化（大部分工作中令其为零）和由二值指示变量 s^{μ} 控制的分批；对数据集中的每个点，以概率 γ 抽取该变量：

$$\widehat{w}_i(t+1) = \widehat{w}_i(t) - \eta \frac{\partial \left[\frac{1}{2} \sum_{\mu=1}^{n} s^{\mu} (\widehat{y}^{\mu} - y^{\mu})^2 + \frac{\lambda}{2} \|\widehat{\boldsymbol{w}}\|_2^2 \right]}{\partial \widehat{w}_i(t)}. \tag{6.11}$$

接下来作者如第 6.1 节一样构造 MSRJD 积分；对无序（数据集、初始化、批次选择和标签噪声）取平均并求泛函导数，得到作为主要研究对象的关联与响应函数。我们略去大部分细节，但值得展示起点——梯度流的动力学配分函数，如第 6.1 节所说等于一：

$$\begin{aligned} Z_{\mathrm{dyn}} = \int \mathcal{D}\widehat{\boldsymbol{w}}(t) \prod_{i=1}^{d} \delta \Bigg[& - \partial_t \widehat{w}_i(t) - \lambda \widehat{w}_i(t) + j_i(t) \\ & - \sum_{\mu=1}^{n} s^{\mu}(t) \frac{x_i^{\mu}}{\sqrt{d}} \left(\sum_{k=1}^{P} \frac{x_k^{\mu}}{\sqrt{d}} (\widehat{w}_k(t) - w_k^*) - \epsilon^{\mu} \right) \Bigg] = 1. \end{aligned} \tag{6.12}$$

我们希望突出这一方程的一般结构：它是一个作用量的路径积分，源同时与“物理”参数场和响应场耦合，

$$Z_{\mathrm{dyn}}[\boldsymbol{j}, \widetilde{\boldsymbol{j}}] = \left\langle \int \mathcal{D}\widehat{\boldsymbol{w}}(t)\, \mathcal{D}\widetilde{\boldsymbol{w}}(t)\, \exp\left(S_{\mathrm{dyn}} + \sum_{i=1}^{P} \int \widetilde{j}_i(t) \widehat{w}_i(t)\, dt + \sum_{i=1}^{n} \int j_i(t) \widetilde{w}_i(t)\, dt \right) \right\rangle, \tag{6.13}$$

这是统计场论中很常见的对象！一般而言 S_{dyn} 包含理论的全部微观细节，而这里是一个相当易于处理的特殊模型；一般情况下我们没有这么幸运。尖括号表示对输入数据集 $\{\boldsymbol{x}^{\mu}\}_{\mu=1}^{n}$、初始条件 $\widehat{\boldsymbol{w}}(0)$、随机抽样 $s_{\mu}(t)$ 和加入的标签噪声 $\{\epsilon^{\mu}\}_{\mu=1}^{n}$ 取平均。作为轻松调剂，我们还写出对淬火

无序积分后的完整动力学生成函数：

$$
\begin{aligned}
Z_{\mathrm{dyn}} \propto \int \mathcal{D}\boldsymbol{\mathcal{B}}(t) \int \mathcal{D}\mathcal{Q}(t,t')\, \exp\Big(& - i\widetilde{\boldsymbol{w}}\, \partial_t \widehat{\boldsymbol{w}} - \lambda P Q_2(t,t) \\
& - P Q_1 \cdot \widehat{Q}_1 - P Q_2 \cdot \widehat{Q}_2 - P Q_3 \cdot \widehat{Q}_3 - P Q_4 \cdot \widehat{Q}_4 \\
& - \frac{n}{2} \log\det \begin{pmatrix} \gamma Q_2^{\top} - \gamma Q_4 + \delta & \gamma^2 Q_3 \\ Q_1 + D & \gamma Q_2 - \gamma Q_4^{\top} + \delta \end{pmatrix} + \widetilde{\boldsymbol{j}}\widehat{\boldsymbol{w}} + \boldsymbol{j}\widetilde{\boldsymbol{w}} \\
& + \int\int dt\, dt' \sum_k \big[(\widehat{w}_k(t) - w_k^*) \widehat{Q}_1(t,t') (\widehat{w}_k(t') - w_k^*) \\
& \qquad + i\widehat{w}_k(t) \widehat{Q}_2(t,t') \widetilde{w}_k(t') + i\widetilde{w}_k(t) \widehat{Q}_3(t,t') i\widetilde{w}_k(t') \big] \\
& + \int dt \sum_k i\widetilde{w}_k(t) \widehat{Q}_4(t) w_k^* \Big),
\end{aligned}
\tag{6.14}
$$

其中 $\mathcal{D}\boldsymbol{\mathcal{B}}(t)$ 是动力学场测度 $\mathcal{D}\widehat{\boldsymbol{w}}(t)\mathcal{D}\widetilde{\boldsymbol{w}}(t)$ 的简写，新测度 $\mathcal{D}\mathcal{Q}(t,t')$ 为

$$
\begin{aligned}
\mathcal{D}\mathcal{Q}(t,t') = \left(\frac{P}{2\pi}\right)^4 & \mathcal{D}Q_1(t,t') \mathcal{D}\widehat{Q}_1(t,t')\, \mathcal{D}Q_2(t,t') \mathcal{D}\widehat{Q}_2(t,t') \\
& \times \mathcal{D}Q_3(t,t') \mathcal{D}\widehat{Q}_3(t,t')\, \mathcal{D}Q_4(t) \mathcal{D}\widehat{Q}_4(t).
\end{aligned}
\tag{6.15}
$$

每个 $\mathcal{Q}$ 变量代表两个变量之间的某个关联函数。

6.2.2 通过训练误差与泛化误差概览结果

作者将泛化误差定义为均方误差（MSE）：

$$
\epsilon_g(t) = \left\langle \left(\frac{1}{\sqrt{P}} \sum_{i=1}^{P} x_i^0 [\widehat{w}_i(t) - w_i^*] - \epsilon^0 \right)^2 \right\rangle. \tag{6.16}
$$

取热力学极限后，泛化误差可用 DMFT 方程确定的等时关联函数 $C(t,t)$ 及噪声方差 D 表示：

$$
\epsilon_g(t) = C(t,t) + D. \tag{6.17}
$$

作者得到这一关系的两种形式，并在临界点附近提出第三种标度关系。对于 $\lambda = 0$、$\nu < 1$，渐近误差为

$$
\epsilon_g(t \to \infty) = D(\gamma\chi + 1) = \frac{D}{1 - \nu}. \tag{6.18}
$$

注意接近临界性时出现的极点。量 $\chi = \int_0^{\infty} R(\tau)\, d\tau$ 称为**积分响应率**（susceptibility）；只有当响应函数衰减时，即只在平衡态中，它才良好定义。它出现在这里表明这一相中对初始条件扰动的响应确实衰减：在渐近极限下，系统不再记住初始化。

具有持久记忆的非遍历相表现为渐近泛化误差显式依赖保留的初始条件 $C(0,0)$，并且在 $\nu \to 1$ 时仍显示与临界附近 $\nu < 1$ 区域类似的敏感性：

$$
\epsilon_g(t \to \infty) = \frac{(\nu - 1) C(0,0)}{\nu} + \frac{D\nu}{\nu - 1}, \tag{6.19}
$$

其中完整表达为 $C(0,0) = \langle \widehat{w}^2(0) \rangle + r$。$\langle \widehat{w}^2(0) \rangle$ 是初始化的方差，r 是真实参数每维均方范数。注意，此时响应函数不衰减，因为系统保留了初始条件的记忆。它饱和到 $R(\tau \to \infty) = (\nu - 1)/\nu$；作者称此为遍历性破缺程度，它量化对初始化所施加扰动的持久记忆。

训练误差也表现出类似趋势：对于 $\nu < 1$，模型仍在尝试逼近解，所以误差渐近有限；对于 $\nu > 1$，依赖初始化的记忆确保模型总能准确处理训练数据，所以训练误差消失。作者将训练误差写作

$$\lim_{t\to\infty} \epsilon_t(t) = (\gamma\chi + 1)^{-2}\epsilon_g(t \to \infty). \tag{6.20}$$

对于 $\nu < 1$, 它简化为 $D(1-\nu)$; 而对于 $\nu > 1$, 系统不再处于平衡态, 积分响应率 $\chi = \int_0^\infty R(\tau)\, d\tau$ 发散，使训练误差趋于零。

为刻画 $\nu \approx 1$ 附近模型的临界行为，作者计算临界指数 (σ, φ) 并提出标度函数。第一部分较直接：由式 (6.18) 和 (6.19) 可见，当 $\nu \to 1^{\pm}$ 时，$\epsilon_g(t \to \infty)$ 从两侧发散。这提示标度 $\epsilon_g(t \to \infty) \sim |1-\nu|^{-\sigma}$，DMFT 中指数为 $\sigma = 1$。我们提醒读者：这是渐近长时间稳态结果，训练误差和泛化误差都依赖时间。

由于饱和时间依赖 ν，相变的一般特征是转变附近应出现动力学标度数据坍缩 [33]。作者据此提出如下标度假设：

$$\epsilon_g \approx \frac{D}{|1-\nu|^{\sigma}} \mathcal{F}\left[\frac{|1-\nu|^{\varphi}(\gamma t)}{4}\right], \tag{6.21}$$

其中引入了新的临界指数 φ 和普适标度函数 $\mathcal{F}(z)$, γ 仍是样本被纳入的概率。作者对临界点附近及临界点处 $\mathcal{F}$ 的形式作了两项观察。首先，在点的附近 $\nu \to 1^{\pm}$ 对应 $z \to 0$，他们认为前面的奇异性必须被吸收入 $\mathcal{F}$，因此它采取渐近形式 $\mathcal{F}(z) \sim z^{\sigma/\varphi}$。其次，在 $\nu = 1$ 时，由于泛化误差随时间增长而非饱和，有 $\epsilon_g(t) \sim (\gamma t)^{\sigma/\varphi}$。因而指数 φ 刻画随训练时间的这一增长。特别地，式 (6.21) 的形式意味着一个特征时间尺度，记作 $\tau(\nu) = (\gamma|1-\nu|^{\varphi})^{-1}$，用于描述误差标度的收敛。由于误差增长，预期它在 $\nu \to 1$ 时发散，实际也确实如此；这是相变的标志性特征，称为临界慢化。例如在晶格系统的 Monte Carlo（MC）计算中，它表现为自关联时间增长：接近临界点时需要更多时间才能得到不相关的样本。在尝试用 MC 技术精确测量临界指数时，人们投入大量精力设计方法绕过这一慢化；它也激励人们在适用时选择完全不同的方法，如 RG 流或共形自举 [33]。

习题 6.2（实验中的双下降）。 模拟本小节模型：教师 $w^* \sim \mathcal{N}(0, rI_P)$，输入 $x^{\mu} \sim \mathcal{N}(0, I_P)$，标签 $y^{\mu} = w^* \cdot x^{\mu}/\sqrt{P} + \epsilon^{\mu}$，噪声方差为 D；学生 $\widehat{w}$ 按更新式 (6.11) 训练，取岭参数 $\lambda = 0$ 和全批次 $\gamma = 1$，初始化为 $\widehat{w}(0) \sim \mathcal{N}(0, \sigma_0^2 I_P)$。取 $P = 200$ 和 $\nu = P/n \in \{0.5, 0.9, 1.1, 2\}$。

(a) 绘制训练误差和泛化误差随时间的变化，并验证渐近式 (6.18)、(6.19)，包括当 $\nu \to 1$ 时两条分支的发散：在时间上分辨出的双下降。

(b) 检查遍历性破缺：运行两个副本，其初始化相差一个小的随机扰动 $\delta\widehat{w}(0)$，追踪归一化距离 $|\Delta\widehat{w}(t)|^2/|\Delta\widehat{w}(0)|^2$。验证它在 $\nu < 1$ 时衰减至零，在 $\nu > 1$ 时则饱和——其平台值为预测的 $(\nu-1)/\nu$，即论文中的遍历性破缺程度；用二十行代码即可测量。

(c) 在 $\nu = 1$ 附近，提取 $\epsilon_g(t)$ 的弛豫时间，并检验式 (6.21) 给出的临界慢化 $\tau \sim |1-\nu|^{-\varphi}$。

6.3 动力学平均场理论（DMFT）

第 6.2 节是动力学平均场理论的一个实例。DMFT 是减少相互作用动力学系统中有效自由度数目的一般策略：追踪单个代表性自由度，它在替代所有其他自由度的涨落背景中运动；然后要

求背景的统计由代表性轨迹自身的统计自洽决定。这与讲义中的其他平均场具有同样的三步结构（通过平均耦合；论证涨落受控；自洽闭合），只是从标量和测度升级到双时间函数。一篇在生物物理背景中建立直觉的优秀教程是 [8]，[23] 则是广泛的现代综述。在量子多体理论中，同样的思想对原本难以处理的系统极为有效 [31, 46]。下面先澄清动力学设定中的自洽性含义，再概览近期深度学习文献；后者一个自然的技术入口是感知机的非平衡 DMFT[1]。

6.3.1 自洽性

自洽性指要求理论的预测与得到这些预测所使用的近似相一致。一个取自 [85] 的简单例子使问题变得直观（习题 6.3 将详细计算）。考虑随机过程 $dx(t) = f(x(t))\,dt + dW(t)$，其中 W 是 Wiener 过程（因而 $\dot{W}$ 是第 6.1 节的白噪声），并假设 $f(x_0) = 0$ 且 $f'(x_0) < 0$，即 x_0 是无噪声动力学的稳定不动点。可围绕它展开，写 $x(t) = x_0 + \delta x(t)$，得到近似

$$\frac{d}{dt}\delta x(t) = f'(x_0)\delta x(t) + \xi(t) + O(\delta^2 x(t)), \tag{6.22}$$

其中 ξ 也是零均值高斯白噪声。[15]可以通过 Fourier 变换直接计算这些涨落的均值和方差；在时间表象中，方差为 $\langle \delta x^2 \rangle = D/[-2f'(x_0)]$。然而，利用这些结果将 $f(x)$ Taylor 展开至二阶，会给均值带来修正：

$$\langle x \rangle \approx x_0 + \frac{1}{2}\frac{f''(x_0)}{f'(x_0)}\frac{D}{2f'(x_0)}, \tag{6.23}$$

它与构造近似时为均值假定的 x_0 不一致：噪声经 f 的曲率过滤后，会移动我们所展开的点本身。

习题 6.3（最简单例子中的自洽性）。

(a) 推导线性化动力学的平稳方差 $\langle \delta x^2 \rangle = D/[-2f'(x_0)]$（比较习题 6.1(b)）。

(b) 将 f 的 Taylor 展开保留到二阶，推导所给出的均值修正。

(c) 提出自洽修正：改为围绕一点 x_* 展开，选择它使有效漂移为零，即 $f(x_*) + \frac{1}{2}f''(x_*)\langle \delta x^2 \rangle_* = 0$，同时确定 $\langle \delta x^2 \rangle_* = D/[-2f'(x_*)]$。注意这里的结构：两个耦合方程，每个都是另一个的输入——这是第 5.1 节 Curie–Weiss 条件及将要讨论的 DMFT 方程的微型版本。

一种解决该问题并试图确保所围绕展开的小参数确实是展开参数的框架，是使用 n 粒子不可约（nPI）有效作用量。完整讨论远超本文范围，但一篇教学性介绍 [7] 对此讲得很好，其主要思想是通过越来越多的多局域源生成 n 点关联函数，以强制实现自洽。该文第一节强调，对非谐振子使用标准微扰论会产生所谓长期项（secular terms）：它们是时间 t 的幂，出现在实际展开参数 ϵ 旁边；而使用 nPI 框架能在 ϵ 的每一阶正确重求和这些项。1PI 方法与平均场理论中的局域近似直接相关；在 2PI 方法中，自洽决定的对象是两点函数，它在局域近似下与局域传播子有关，并构成动力学平均场理论的基础。

[15]译注：式 (6.22) 的余项 $O(\delta^2 x(t))$ 按原文记号保留；通常的涨落展开写作 $O((\delta x(t))^2)$，原文未进一步澄清此处记法。

6.3.2 近期深度学习应用

幸运的是，实践中很少需要一般的 nPI 全套工具。工作路线在结构上与物理学中求解大 N 模型（如 SYK 模型的 G–Σ 形式）的技巧相同：通过 delta 函数为关联与响应函数引入双局域集体场，正如第 6.2 节的 Q，然后在适当的 $N \to \infty$ 极限下用鞍点法计算它们的路径积分。这就是 [12, 9] 的深度学习 DMFT 的构造方式。

下面按照年代先后，带有主观判断地简要介绍相关文献。

自旋玻璃起源。 无序系统的平均场动力学是这些工具形成的地方。Amit、Gutfreund 和 Sompolinsky[3] 将自旋玻璃方法带入神经网络（以 Hopfield 式联想记忆的形式）；Sompolinsky、Crisanti 和 Sommers[83] 推导了随机循环网络的 DMFT，发现一个通向混沌的转变。需要记住的结构点是：伊辛磁体那样的有序系统只有一个整体耦合 $J\sum_{\langle ij\rangle}\sigma_i\sigma_j$，已经很难处理；无序系统具有随机耦合 $\sum_{ij}J_{ij}\sigma_i\sigma_j$，而正是这种全连接随机性使平均场方法变得精确——从第 2 节的感知机开始，数据依赖耦合给学习问题带来了同样的结构特征。

Bordelon–Pehlevan 研究计划。 对于固定数据集、用梯度下降训练的深网络，文献 [12] 的 DMFT 取无限宽极限，发现序参量恰是特征核 $\Phi(t,s)$ 与梯度核 $G(t,s)$，它们是第 3–4 节 NNGP 核与 NTK 的双时间推广。当这些核冻结时，恢复第 4 节的惰性区域；丰富的特征学习动力学则是它们自洽计算得到的真实演化。（预先提醒：记号很繁重——响应场和共轭序参量随处可见——但结构恰是 MSRJD 加上鞍点。）这一研究计划现在包括有限宽度核涨落 [13]、跨深度超参数迁移 [11] 以及神经标度律的动力学理论 [9]，后者将在第 7.9 节再次出现。

Mignacco–Urbani 系列工作。 另一系列工作以维数与样本数成比例的标度将数据视为淬火无序，延续第 2 节的思路：高斯混合分类的 DMFT[58]，以及对长时间 SGD 有效噪声的 DMFT 刻画 [59]；后者是第 2.1 节批次噪声讨论的动力学细化。

严格性。 最初的物理启发式正在越来越多地变成定理：一阶方法的严格 DMFT 推导现已存在 [17, 32]，并有不断扩展的研究，例如推广到自适应 Langevin 扩散，同时给出混沌传播保证和线性响应的收敛 [27]。近期这一方向的一项杰出工作 [60] 大规模求解了双层网络动力学；计算漫长，但论文组织良好。其结果包括：与网络复杂度（高斯 / Rademacher 意义下）增长相关的慢时间尺度出现；当初始化复杂度低时偏向低复杂度的归纳偏置；特征学习与过拟合区域在动力学上的解耦；以及非单调测试误差，其中很长时间后存在“特征遗忘”区域。

本节各部分的联系值得再说一次：MSRJD 路径积分对于训练动力学的作用，就如 Gibbs 测度对于贝叶斯学习——它是一个对象，在其上可以施展各种物理技术，包括鞍点、无序平均、集体场和微扰论。

7 标度律

在最后一节，我们回到第 1 节的主题，讨论神经标度律。在许多个数量级范围内，大模型的测试损失随投入的每种资源——参数、数据和计算量——以清晰的幂律下降。这些定律由测量数据的曲线拟合得到，已被证明是极为简单、稳健且影响深远的经验观察，任何成功的深度学习模

型都应能够解释。许多模型确实捕获了它们的形式，其中一些还进一步基于数据分布的特征对指数作出定量预测。

本节的组织问题是：指数从何而来？我们先汇集经验图景（第 7.1–7.2 节）：三个定律、每个定律固定了什么，以及支配计算最优训练的联合定律；Kaplan 与 Chinchilla 的差异正出现在这里，也在这里得到解决。随后转向理论。第 7.3 节说明各提案共同的机制——数据中的幂律产生损失中的幂律——第 7.4 节以表格概览主要提案。其余部分按所需工具复杂度递增，详细讨论表中四类方法：技能的频率统计（第 7.5 节，作为自行推导的习题进行，并在第 7.6 节用于解释“涌现能力”）；数据几何与核谱（第 7.7 节）；以及可解的大 N 场论，先静态后动力学（第 7.8–7.9 节）。最后介绍目前尚无理论解释的最新测量：后训练与测试时标度（第 7.10 节）。

记号。 沿用本讲义约定：P 是参数数目，n 是数据集大小。请注意，标度律文献用 N 表示我们的 P，用 D 表示我们的 n（它们的 N 不是我们的宽度！），因此著名的指数 α_N, α_D 对应这里的 α_P, α_n。阅读原文献时可用下表 [44, 41, 57, 55]：

本讲义	标度律文献
P（参数数目）	N
n（数据集大小）	D
α_P, α_n（指数）	α_N, α_D
m（已学习的量子，第 7.5 节）	n

还需注意，本节无下标的 α 表示量化模型的 Zipf 指数，不是第 2 节的负载。

7.1 经验定律

Kaplan 等人 [44] 对自回归语言模型建立了如下结果：当模型不受其他资源瓶颈限制时，其测试损失满足

$$L(P) \propto P^{-\alpha_P}, \qquad L(n) \propto n^{-\alpha_n}, \qquad L(C) \propto C^{-\alpha_C}, \tag{7.1}$$

其中 P 为（不含嵌入层的）参数数目，n 为以词元计的数据集大小，C 为以 FLOPs 计的训练计算量。测得指数为 $\alpha_P \approx 0.076$、$\alpha_n \approx 0.095$、$\alpha_C \approx 0.050$，趋势最多跨越七个数量级。三个资源核算要点通常被隐含，追问定律来源之前值得先明确它们。

为什么用 FLOPs，以及为什么 $C \approx 6Pn$。 计算量用浮点运算次数衡量，因为 FLOPs 是唯一不依赖任务如何运行的训练投入度量。墙钟时间依赖硬件与并行程度。训练步数则依赖批量大小：相同的 n 个词元可以组成一个巨大批次，也可以组成一百万个小批次；在“临界批量大小”以下（[44] 单独测量了它），损失只依赖处理过的词元数。FLOPs 计算算术运算本身，而能源和费用也与之成正比。标准估计为

$$C \approx 6Pn. \tag{7.2}$$

每个词元的前向传播约花费 $2P$ FLOPs：基本上每个参数都位于某个矩阵乘法中，使用一次，即一次乘法加一次加法。反向传播约为前向传播的两倍，因为每层都需要关于激活和权重的梯度，这对应两次与前向传播规模相同的矩阵乘法。每词元共 $6P$ FLOPs，再乘以 n 个词元。“$\approx$”吸收了注意力（每词元的成本随上下文长度而非参数数目增长）、嵌入和优化器开销。

单轮假设。 估计式 (7.2) 假定每个处理过的词元都是新词元，因此“处理过的词元数”与“数据集大小”是同一个数。在测量这些定律的运行中确实如此：所处理的词元数远少于完整遍历语料一轮所需的数量。概念上二者是不同资源：统计资源是不同词元的数量 n；计算资源是处理过的词元数，在 E 轮训练中为 $T = En$，所以一般 $C \approx 6PT$。固定 n 而通过重复增加 C，获得的是优化而非统计收益：损失收敛到由 n 限制的下界，然后过拟合。用第 2.1 节的语言说，更多训练轮数意味着固定淬火样本下更大的 β，而新数据会改变淬火自由能本身。经验上，单轮理想化有一定容错：在约四轮以内，重复词元几乎与新词元一样有价值，此后其价值迅速衰减 [61]。如今前沿训练受数据限制越来越明显，这一点也愈发重要。

计算量定律不是独立的。 由于 $C \approx 6Pn$ 只依赖另外两个资源，计算量如何成为不受瓶颈影响的资源？答案是，$L(C)$ 通过另一种协议测量：它是下包络

$$L(C) = \min_{P,n:\, 6Pn=C} L(P, n), \tag{7.3}$$

通过训练许多不同尺寸的模型、对每个计算量保留最低损失得到。在这条曲线上，计算量按构造就是起约束作用的资源，而“不受瓶颈限制”意味着“已最优分配”。这使 α_C 成为导出指数。对加性联合定律 $L = AP^{-\alpha_P} + Bn^{-\alpha_n}$，在固定 Pn 时最小化会平衡两项，得到

$$\frac{1}{\alpha_C} = \frac{1}{\alpha_P} + \frac{1}{\alpha_n}, \qquad P \propto C^{\alpha_n/(\alpha_P+\alpha_n)}, \qquad n \propto C^{\alpha_P/(\alpha_P+\alpha_n)}. \tag{7.4}$$

调和和关系使 α_C 小于任意一个单资源指数，因为计算量增长必须分配给参数 P 和数据 n 两者。Kaplan 的数值给出 $\alpha_C \approx 0.042$，而测量值为 0.050：二者大致相符，差距可追溯至拟合形式和提前停止的细节。

普适形式；依赖数据的指数。 相同的幂律形式远不止出现在语言中。Henighan 等人 [39] 在多种数据上训练自回归 Transformer，处处都发现了幂律，但指数随数据而变：

模态	α_P	α_C
语言	0.070	0.048
图像 32×32	0.13	0.10
图像 8×8	0.24	0.19
视频	0.24	0.14
数学（程序生成）	0.16	0.17

（这里的“数学”指程序生成的问题，风格类似 DeepMind 数学数据集。它们由已知程序生成，因此供给实际上无限。记住这一情形：它是唯一数据分布有闭式表达的模态。）不同模态之间指数相差 3–5 倍。相比之下，架构几乎无关紧要：在合理架构范围内，改变形状（固定尺寸下的深度与宽度）甚至架构家族，会改变常数和平台，而非斜率 [44]。这种不对称性是本节的核心线索：决定指数的因素存在于数据中。第 7.7 节将使它定量化。

7.2 联合定律、瓶颈与 Chinchilla 修订

每个单资源定律都假定其他资源无限。联合拟合描述向瓶颈状态的交叉，此时损失由最稀缺的资源支配。文献中有两种占主导的参数形式。Kaplan 等人采用

$$L(P, n) = \left[\left(\frac{P_c}{P} \right)^{\alpha_P/\alpha_n} + \frac{n_c}{n} \right]^{\alpha_n}, \tag{7.5}$$

而 Hoffmann 等人的 Chinchilla 分析 [41] 使用加性假设重新拟合：

$$L(P, n) \approx E + AP^{-0.34} + Bn^{-0.28}. \tag{7.6}$$

加性形式容易理解。$E \approx 1.69$ 是文本不可约熵，即无论规模多大都无法消除的噪声底；两项损失差额各自独立衰减；瓶颈就是较大的差额。在相应边界区域内，两种形式都退化为单资源定律 (7.1)。

这两种拟合的差异在实践中非常重要，因为它们对式 (7.3) 的计算最优分配给出了不同结论。Kaplan 等人的分析得到 $P \propto C^{0.73}$、$n \propto C^{0.27}$：增加计算量时应增大模型。在两年间，这一领域用相对较少的数据训练了越来越大的模型。Chinchilla 的拟合给出 $P \propto C^{0.5}$、$n \propto C^{0.5}$：两者同等增长，或者粗略地说每个参数对应约 20 个词元。这个预测受到直接检验。在 DeepMind 的 2800 亿参数 Gopher 的计算预算下，新规则要求用四倍的数据训练小四倍的模型；得到的 700 亿参数 Chinchilla 在各方面都胜过 Gopher。（两个模型及该定律都沿用 DeepMind 的动物命名系列。）Chinchilla 分配如今是公认的基线。

Porian 等人 [66] 后来分析了这种差异：Kaplan 的拟合受到三个小规模伪影的扭曲——最后一层和嵌入的计算量如何计数、过长的预热以及未随规模重新调节的优化器设置——纠正后两组实验结果一致。还有一个后续现象：前沿模型如今有意相对于 Chinchilla 进行超量训练，使用远多于每参数 20 个词元，因为相同损失下较小模型的推理成本更低，而训练计算量最优分析看不到这一成本。

汇集经验图景后，关于式 (7.1) 的理论应当解释：(i) 为什么幂律能跨越如此多数量级；(ii) 指数的数值（为什么如此小？为什么随模态而非架构变化？）；(iii) 指数间的关系（α_n 由 α_P 决定吗？）；以及 (iv) 定律何时失效。下面综述的各模型分别回答其中一部分。

7.3 定律从何而来？

下面综述的每一种提案共同的基本答案是：损失曲线读出了数据中结构的粗粒化分布。幂律随数据进入，又在损失中出现。

“输入幂律”的原型是 Zipf 定律：将大型语料中的词按频率排序，排名为 k 的词的频率按 $f_k \propto 1/k$ 衰减，覆盖约四个排名数量级（图 7）。这是一个包含越来越罕见结构的无标度尾部，且不限于词。由连续 n 个词组成的序列（n-gram，神经网络之前语言建模的单元）对每个 n 都类似 Zipf 分布，且 n 增大时斜率变平。事实，即文本中记载的离散世界知识，继承了所提实体的重尾流行度；模型回答事实性问题的能力与支持该事实的训练文档数相对应 [43]。文本和图像数据的协方差谱与核谱也被测得服从幂律（第 7.7–7.8 节）。

处理这类数据的学习器永远不会耗尽可吸收的结构。它不断沿尾部向下推进，回报越来越慢。从定性上看，这就是损失为何呈幂律而非指数规律（各尺度都有结构），以及为何不会简单进入平台（尾部没有结束）。这些尾部的指数不同，而且差异很重要，因为下面的每个模型中，损失指数都从数据指数继承而来。纯 Zipf 实际上是边缘情形。将技能频率的尾部写成 $p_k \propto k^{-(\alpha+1)}$。第 7.5 节的量化模型给出的损失指数等于 α；精确 Zipf（$f_k \propto 1/k$，即 $\alpha = 0$）是尾和仅按对数衰减、幂律标度退化的边界。[16]如此理解，语言的测量值 $\alpha_P \approx 0.076$ 意味着其有效技能分布 $p_k \sim k^{-1.08}$，仅比纯 Zipf 略陡。语言标度缓慢，是因为其结构刚好位于临界的 $1/k$ 尾部之上。图像数据的尾部更陡，标度更快；比较第 7.1 节的模态表。

[16]译注：无限词表上的 $p_k \propto 1/k$ 无法归一化，其无限尾和也不收敛。这里的对数边界陈述需结合有限词表或截断理解，不能直接作为下文 $\alpha > 0$ 归一化模型的结果。

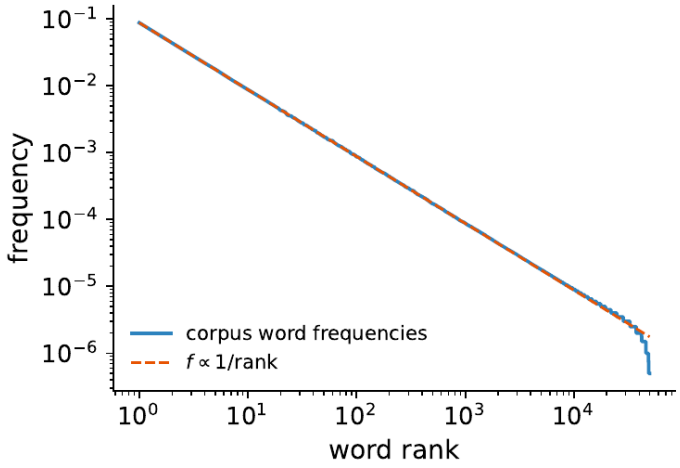


图 7: Zipf 定律在合成语料上的示例：从 5×10^4 个词的词表中按照 $1/k$ 分布抽取 2×10^6 个词元，画出经验排名—频率曲线及 $f \propto 1/$排名 参考线。该曲线是相容性检查而非数据，因为词本来就是从 Zipf 分布中抽样的。真实语料在约四个数量级范围内表现类似，但两端存在偏离：低排名处有 Zipf–Mandelbrot 修正，约 10^4 个词以外尾部更陡。图中文字对照：横轴 “word rank” 为词的排名，纵轴 “frequency” 为频率；“corpus word frequencies” 为语料词频，虚线为 $f \propto 1/$排名。

理论处于什么阶段？ 许多风格完全不同的模型已用这一机制导出了单资源定律，少数模型还导出多资源定律；下面的综述会记录这些进展。仍缺少三件事。第一，没有理论从第一性原理算出数据本身的指数。每个模型都把测得的数据统计量转换成损失曲线，而统计量本身是经验输入。即便对程序生成的数学数据也是如此：其生成程序完全已知，但相关计算尚未完成。第二，还没有包含真正特征学习的联合定律。最好的动力学推导处于惰性的随机特征设定中（第 7.9 节），而可解例子中已知特征学习可改善结构化目标的指数，因此修正未必很小。第三，从平滑损失到能力的桥梁尚缺失。基准表现可能在一个数量级的规模范围内跳跃，而损失平稳滑动 [92]；这一现象被质疑可能是指标造成的伪影 [74]，第 7.6 节的量化模型将给出更清楚的解读。较新的第四个缺口是：第 7.10 节的后训练和测试时标度律完全没有理论。

7.4 理论提案概览

下表按四个问题组织神经标度律中最主要的推导：如何建模数据（等价地说，“特征” 是什么、如何分布）；如何建模网络（如果有网络）；是否预测实际指数、依据什么预测；以及是否得到多资源定律。

提案	数据模型 / “特征”	神经网络框架	指数?	多资源?
量化；Michaud 等 [57]	离散技能“量子”，按 Zipf 频率使用、按序学习	无（计数论证）	由 Zipf 指数 α 给出；还有关系 $1/\alpha_n = 1/\alpha_P + 1$	分别得到 P, n, S 定律
数据流形；Sharma–Kaplan[78]	d 维流形上的光滑目标	分段线性插值（只涉及函数类；无训练）	是：$\alpha_P \approx 4/d$	否（仅 P）
渗流；Brill[14]	临界状态下的潜在子任务簇，簇大小服从幂律	无：一般非参数学习器加回归估计	来自渗流临界指数	两个区域；非联合
核本征学习；Bahri 等 [5]，Bordelon–Canatar–Pehlevan[10, 16, 79]	幂律核谱及目标系数	冻结核：无限宽 NTK 或 GP / 贝叶斯	由谱指数给出	部分得到：分辨率受限与方差受限区域
可解场论；Maloney–Roberts–Sully[55]	潜在幂律协方差，并由随机特征扩展	固定随机特征上的线性模型（冻结核）；大 N 随机矩阵理论，静态	由数据谱指数给出	是：联合 $L(P, n)$，具有 $P \leftrightarrow n$ 对偶
DMFT；Bordelon–Atanasov–Pehlevan[9]	幂律（源 / 容量）谱	固定随机特征上梯度流训练的 DMFT（冻结核；动力学）	是，包括时间指数	完全联合 $L(t, P, n)$ 与计算量前沿

阅读此表有五点说明。第一，所有人都认同来源：每一行的损失指数都继承自数据中的某种幂律尾部，无论是技能频率、簇大小、流形体积还是协方差谱。各行的差异在于尾部是什么的尾部，以及保留了多少网络机制。

第二，这一点值得强调：只要建模网络，表中每一行都使用冻结核。本征学习一行使用第 4.3 和 4.6 节的无限宽 NTK 或 GP 核；两行场论只训练固定随机特征集的读出层，因而按构造就是冻结核（习题 B.6(b)）。流形一行只将网络函数类建模为线性片段数目，并不训练它；量化和渗流两行没有网络。因此目前没有任何推导包含特征学习，而第 5–6 节认为这一机制正是有限网络不同于核的原因。

第三，在有重叠的地方，平衡态路线（贝叶斯 GP 学习曲线及其有限宽修正）与动力学路线（梯度流、DMFT）给出匹配的指数。这是第 2.1 和第 6 节中“一个系统的两个极限”对应关系的又一次体现。第四，目前只有两行场论预测联合定律，并且只有动力学一行将训练时间计入成本，推导而非假定了类似 Chinchilla 的计算最优前沿。第五，没有任何一行计算数据本身的指数。

最接近的尝试是渗流提案：它从数据分布的临界模型推导簇大小的幂律统计；其两个临界区域——服从幂律分布的离散子任务和占主导地位的数据流形——分别对应量化和流形两行。我们不再进一步展开渗流模型。余下各小节将按工具复杂度顺序研究其他几行。

预测指数与实验一致吗？已经进行比较的地方，答案令人鼓舞，但尚不够精确。量化模型的作者通过对梯度聚类，从一个小型语言模型中提取“量子”，测量每个量子在训练分布中的使用频率，并发现其幂律指数与模型的标度指数大致匹配，正如模型所要求的 [57]；另一方面，模型对 α_P 与 α_n 的无参数关系与 Kaplan 测得的指数次序不符（习题 7.1(e)）。流形预测 $\alpha_P \approx 4/d$ 在教师—学生实验中得到证实，那里 d 和 α_P 可独立测量；它也在图像分类器和 GPT 型语言模型上得到较粗略的检验 [78]。对于语言，如果直接采用 $\alpha_P \approx 0.076$，得到 $d \approx 50$（习题 7.2）。核预测已在标准架构与数据集上检验，指数由实测核谱计算；预测的 P 与 n 指数对偶关系得到了支持 [5]。两行场论将数据谱指数作为输入。它们的定性预测——指数与架构无关、$\alpha_P \approx \alpha_n$、计算最优规则为参数与数据等比例配置——与 Chinchilla 时期的测量相符，但定量检验需要训练数据的协方差谱，而大型运行很少报告该谱。诚实的总结是：这些理论把从数据中测得的指数转换为从

损失中测得的指数；在两者都已测量的地方，这一转换经受住了检验。

7.5 量化模型：从技能统计得到指数

Michaud、Liu、Girit 和 Tegmark 的量化模型 [57] 是一个最简标度模型。它没有架构、没有优化器，除了尾和之外基本没有数学工具，却能产生式 (7.1) 的全部三个定律，并为“涌现能力”提供鲜明视角。名称有意带有挑衅意味：该提案认为网络学习到的东西由离散单元组成，称为量子。[17]我们使用的假设形式为：

- **QH1（离散性）**。与预测任务有关的计算和知识分解成可枚举的量子：基本技能或事实（例如“逢十进一”、“‘法国首都是’后面接巴黎”等）。每个量子要么完全学会，要么完全没有学会，没有部分得分。
- **QH2（按序获得）**。网络大致按照用处递减的顺序学习量子，因此给定模型已经学会固定序列中的前 m 个量子。
- **QH3（Zipf 式使用）**。第 k 个量子在以下比例的样本中使用：

$$p_k = \frac{k^{-(\alpha+1)}}{\zeta(\alpha+1)}, \tag{7.7}$$

其中 $\alpha > 0$ 为常数；在这些样本上，掌握它会使损失降低常数 Δ，该常数与 k 无关。

因此，已学会前 m 个量子的模型，其期望损失为

$$L_m = L_\infty + \Delta \sum_{k>m} p_k. \tag{7.8}$$

这就是整个模型。其他所有问题都是在问 m 如何受各项资源限制。

习题 7.1（三个假设导出三个标度律）。 （⋆）

(a) 估计式 (7.8) 的尾和，证明 $L_m - L_\infty \propto m^{-\alpha}$。

(b) *参数受限（数据和训练无限）*。假设学习每个量子都需要固定的 c 个参数容量。用 α 导出 α_P。

(c) *数据受限（容量和训练无限）*。假设一个量子只有在至少 τ 个训练样本中被使用才可学习，其中 τ 为常数。给定 n 个独立同分布样本，哪些量子可学？导出 α_n。

(d) *训练受限、单轮*。假设学习量子 k 需要在包含它的批次上进行 τ 次梯度更新。在线训练 S 步（批次均为新数据）之后，导出 α_S。

(e) *可证伪性*。(b)–(c) 预测了 α_P 与 α_n 的无参数关系：写出它，并指出两个指数哪个必然更大。与式 (7.1) 之后引用的实测值比较。某个地方有问题——是什么？列出你使用的假设，讨论哪些最可疑。（这是没有定论的讨论题；候选解释见解答。）

[17] Michaud 的博客文章 `https://ericjmichaud.com/quanta` 是论文极好的配套材料，在本习题中可代替论文。但请在读它们之前尝试习题 7.1；推导简短，自行发现比跟随别人更有启发。

7.6 涌现：由错开的悬崖组成平滑定律

量化模型最深刻的收获在概念层面。按 QH1，任何单个量子的学习都是阶跃函数：一种能力先是不存在，随后突然出现。然而，总损失 (7.8) 是平滑幂律。这并不矛盾：*平滑定律是许多错开的悬崖之和*，每个悬崖以 p_k 加权，在总量中单独不可见，因为量子 k 对损失只贡献很小的比例 p_k。

Michaud 等人用遗传学隐喻进一步阐明这一点。如果一个测试样本的损失由单个量子支配，则它是*单基因的*，其训练过程中的损失曲线呈现一个平台后接悬崖；如果许多量子都有贡献，则它是*多基因的*，其损失平滑下降。这两类逐词元曲线都在真实大语言模型中被观察到。从这个视角看，“涌现能力” [92] 既非魔法也非幻象 [74]：任何被少数量子支配的基准都必然显示突然而至，而任何充分聚合的指标都必然呈现平滑。涌现是所测对象的性质，不（必然）是模型内部相变的性质。

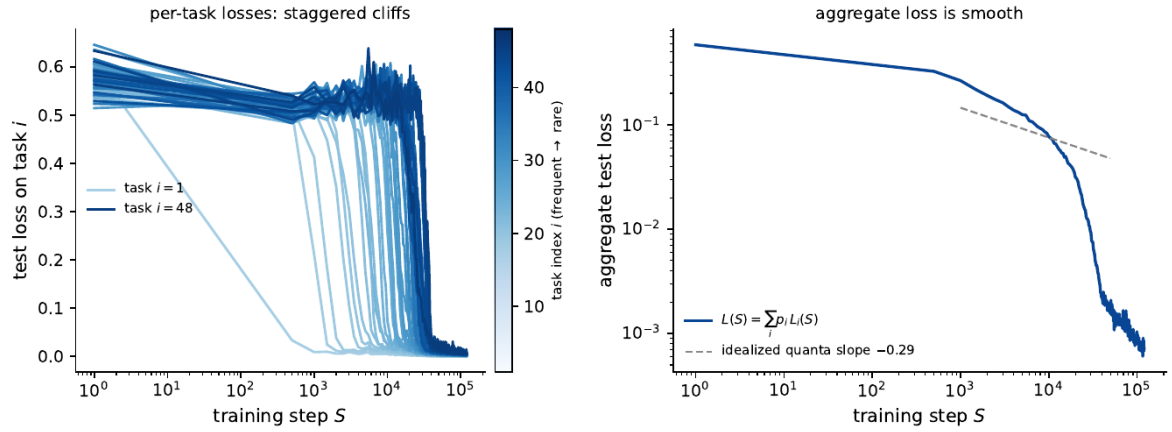


图 8: 多任务稀疏奇偶校验 [57]：错开的悬崖产生平滑标度。设定：$T = 48$ 个子任务，频率服从 Zipf 形式 $p_i \propto i^{-(\alpha+1)}$，$\alpha = 0.4$；输入是独热任务指示向量（$T$ 比特）与 24 个随机 ± 1 比特的拼接；标签是一个固定随机三元素比特子集的奇偶性，子集随任务变化。模型：单隐藏层 ReLU MLP，宽度 512，对 ± 1 标签使用 MSE 损失，在线训练（每批 256 个新样本；Adam，学习率 2×10^{-3}，1.2×10^5 步；随机种子固定）。左：每个子任务的测试损失随训练步数变化，各任务在突降中被学会，频繁任务优先。右：按频率加权的总损失 $L(S) = \sum_i p_i L_i(S)$ 平滑；虚线参考为习题 7.1(d) 中理想化量子模型的斜率 $-\alpha/(\alpha+1)$。实测衰减明显更陡，正文将讨论这一点。图中文字对照：两图横轴为训练步数 S，左、右纵轴分别为单任务和总测试损失；左图色标的任务编号从频繁任务指向稀有任务，图例特标 $i = 1$ 与 $i = 48$；右图虚线标出的理想化斜率约为 -0.29。

实验：多任务稀疏奇偶校验。 整个机制可放进一台笔记本规模的实验中，如图 8 所示；鼓励学生复现并修改（所有细节见图注）。网络在线训练于 T 个不同的奇偶校验子任务，任务频率呈 Zipf 分布。输入是独热任务指示向量与随机比特的拼接，标签是少量任务特定比特子集的奇偶性。奇偶校验是一种大海捞针式技能，没有部分得分，因而是一个真实手工构造的量子。结果是：每个子任务的测试损失都是错开的悬崖（频繁任务先下降），而按频率加权的总损失平滑衰减。还需注意右图中清楚显示的一处真实失败：测得的总损失衰减比习题 7.1(d) 的理想化量子斜率 $-\alpha/(\alpha+1)$ 更陡，因为悬崖聚集在一起，而非按 Zipf 规律散开；稀有任务比阈值规则 $Sp_k \gtrsim \tau$ 预测得更早

被学到。子任务共享一个隐藏层和一个自适应优化器，所以并非独立学习，习题 7.1(e) 解答中的假设 (iv) 失效。

7.7 从几何与谱得到指数

量化模型以 Zipf 指数 α 作为输入。下面两个论证则由数据性质输出指数。

7.7.1 几何：数据流形论证

Sharma 和 Kaplan[78] 提出最简单的连续机制。ReLU 激活网络计算一个分段线性函数，因此在内禀维数为 d 的数据流形上做回归，是分段线性插值问题。具有 P 个参数的网络可负担约 P 个线性片段；用 P 个片段铺满 d 维流形得到间距 $s \sim P^{-1/d}$；线性片段以约 s^2 的精度逼近光滑目标（Taylor 展开）；MSE 是误差的平方。因此

$$L(P) \sim (s^2)^2 \sim P^{-4/d}, \qquad \alpha_P \approx \frac{4}{d}. \tag{7.9}$$

指数小是因为数据流形的维数高。该公式可以检验，因为 d 可用内禀维数估计器测量，而这正是 [78] 所做的。

习题 7.2（从数据流形得到指数）。

(a) 补全式 (7.9) 的推导，准确指出在哪一步使用了目标函数的光滑性。

(b) 如果损失换成平均绝对误差，答案如何变化?

(c) 若直接采用语言模型的实测值 $\alpha_P \approx 0.076$，估计“文本流形”的有效维数。讨论测量到的是输入维数、嵌入维数还是其他东西。

(d) 如果平铺分辨率受到 n 个样本限制，这一机制对数据指数 α_n 作何预测?

7.7.2 谱：从核本征值得到标度律

第二种机制使用已有工具：第 4.6 节的贝叶斯核回归，其模态滤波公式表明，给定 n 个样本（和逆温度 β），被学习的 GP 核模态满足 $\lambda_k \gtrsim (n\beta)^{-1}$。假设核谱及目标函数的分解都服从幂律，

$$\lambda_k \sim k^{-a} \quad (a>1), \qquad y_k^2 \sim k^{-b} \quad (b>1), \tag{7.10}$$

并共享本征基 $\{\phi_k\}$。未学习的模态支配测试误差：

$$L(n) \sim \sum_{k:\lambda_k \lesssim (n\beta)^{-1}} y_k^2 \sim \sum_{k>k_*} k^{-b} \sim k_*^{1-b}, \qquad k_* \sim (n\beta)^{1/a}, \tag{7.11}$$

因此 $L(n) \sim n^{-(b-1)/a}$：标度指数是谱衰减率的比值。所有关于数据与架构的信息都通过两个可测的幂律进入。这是“本征学习”分析 [10, 16, 79] 的起点；这些分析把式 (7.11) 精化为精确的学习曲线，其中包括产生第 6 节双下降峰的过拟合因子。Bahri 等人 [5] 将可能性组织成简洁的 2×2 分类：分别在 P 和 n 方向，区分分辨率受限区域（指数来自谱或几何，如此处及式 (7.9)）与方差受限区域（普适指数为 1）。

习题 7.3（谱标度律与作为本征模态的量子）。

(a) 从第 4.6 节的模态滤波公式推导式 (7.11)，并检验交叉模态 $k \sim k_*$ 不改变指数。

(b) 在以下对应下证明量化模型的数据标度律是式 (7.11) 中 $b = a$ 的特例：量子对应本征模态，Zipf 定律对应谱，$a = \alpha + 1$。（提示：量子模型中 p_k 同时扮演两个角色：决定学习阈值，以及对损失的贡献 Δp_k，所以两个幂律相同。）

(c) 在量子模型中，$b \neq a$ 意味着什么？设计一种对 QH3 的修改使其实现。

7.8 一个可解的大 N 场论

Maloney、Roberts 和 Sully[55] 提供了上述论证缺少的东西：一个微观、精确可解的模型，在其中联合定律 $L(P, n)$ 是计算出来的，而非人为建模的。其要素包括：一个生成式数据模型，其中观察输入是潜在空间随机投影的（非线性）函数，经过设计使数据协方差具有幂律谱 $\lambda_k \sim k^{-(1+\zeta)}$，正如在真实图像和文本数据中测得的那样（论文用 γ 表示谱指数；我们将 γ 留给第 5.4 节的标度旋钮）；一个随机特征线性学生，因此处于第 4 节的惰性极限，其 P 个随机特征是可训练参数，用 n 个样本训练；以及固定比值下 $P, n \to \infty$ 的联合热力学极限。计算在大 P, n 下进行：对数据和特征的期望变为高斯积分，测试损失成为预解式（Green 函数）的乘积，而 $1/P$ 展开组织成可以精确重求和的平面（'t Hooft）图。[18]

冻结，但随机。 一种自然的第一反应是这个模型应当很平凡：学生是固定随机特征上的线性模型，其核从不移动，所以明确处于第 4 节的惰性区域，而严格的无限宽惰性极限中损失根本不会依赖 P。P 标度律是惰性极限上的有限尺度效应。在有限 P 时，特征 Gram 矩阵是与随机样本相关的随机矩阵，其秩限制学生能够分辨多少个数据谱模态。所有物理都存在于对这一随机性所作的无序平均中，而这正是预解式和平面图所计算的。冻结不意味着确定性。

三个值得注意的结果：

- 指数从何而来：损失继承数据的谱指数，在对数修正以内 $L \sim \min(P, n)^{-\zeta}$。值得注意的是，一般的非线性特征映射会延伸数据的幂律谱，而不是改变其形状。这解释了指数为何大致与架构无关，且只能通过改变数据（或任务）来改善。

- 对偶性与 *Chinchilla*：损失在领先阶对 $P \leftrightarrow n$ 对称。这预测 $\alpha_P \approx \alpha_n$，与观察一致，且在精神上与量子模型的不对称预测相反（习题 7.1(e)）。它使得等参数配置 $P \propto n$ 成为计算最优方案，从第一性原理得到 Chinchilla 规则。

- 定律何时失效：当 $\min(P, n)$ 超过数据模型的潜在维数时，标度停止，损失进入平台。幂律是关于数据中可分辨结构的陈述，而当结构耗尽时它便结束。

7.9 同时调节所有旋钮：动力学理论

迄今所见都是静态理论，或者一次只调节一个旋钮。当前前沿是将第 6 节的动力学平均场理论用于标度问题。Bordelon、Atanasov 和 Pehlevan[9] 在大宽度、大数据和长时间的联合极限下，

[18] 这也是第 6 节工具的一个工作示例：同一模型也可动态求解，在插值阈值 $P \sim n$ 处的双下降峰可被岭正则化或提前停止正则化，对应第 7.7 节提到的过拟合因子发散。

求解了一个用梯度流训练、数据谱为幂律的随机特征模型。他们得到对 $L(t,P,n)$ 的单一自洽预测，以第 6 节的关联函数和响应函数为序参量。每种资源成为起约束作用的限制时，都会贡献自己的幂律，在相应边界区域中恢复第 7.7 节的分辨率受限指数。此外，该理论预测完整的计算最优前沿：在固定计算量 $C \propto Pt$ 时最小化 L，得到类似 Chinchilla 的分配规则和前沿指数，而不是先行假设它们。

一个合理的问题是：这里的特征再次是冻结且随机的，与第 7.8 节设定完全相同，那么动力学平均场理论是否小题大做？不是，原因有二。第一，时间是真正的第三种资源。预测 $L(t,P,n)$ 和计算前沿需要整个训练轨迹，而静态理论只能看到 $t \to \infty$ 的边界。第二，惰性区域中按模态逐个求解、即如式 (4.34) 那样令残差的每个核本征模态按 $e^{-\eta\lambda_k t}$ 衰减的简单方法，只适用于确定性核。这里核的本征值和本征向量是随机的，且与抽取的数据相关，所以无序平均会将模态耦合起来。DMFT 的关联函数与响应函数是第 7.8 节静态预解式的动力学推广；当 $t \to \infty$ 时，方程如预期退化回静态答案。该理论尚未处理的是特征学习。形式的自适应核版本已存在 [12]，但尚未在幂律数据上推进到闭式标度律；这就是第 7.3 节缺少的“具有真正特征学习的联合定律”。由于在可解情形中已知特征学习可改善结构化目标的指数，这种修正未必很小。

7.10 超越预训练：后训练与测试时标度

前沿模型不再只是预训练。它们还在精选示范上微调（SFT）、根据奖励模型或可验证奖励优化（RLHF、RLVR），并在推理时使用可变计算量。标度律是否延伸到这些阶段？越来越多的结果表明是，但函数形式发生变化，而这些变化很有启发。

迁移与微调仍类似 Kaplan 规律。 预训练对下游任务的价值可以量化为有效迁移数据量，即预训练初始化相当于多少微调数据；它分别随微调数据集大小和模型大小按幂律标度 [40]。

奖励模型优化 引入一个新的标度轴：既不是数据也不是参数，而是从基础策略移动的距离 $d = \sqrt{\mathrm{KL}(\pi\|\pi_0)}$。Gao、Schulman 和 Hilton[28] 发现，真实（“黄金”）奖励遵循关于 d 的简单规律：对 n 次采样取最佳值为 $d(a - b\log d)$，对于 RL 为 $d(a - bd)$；系数随奖励模型大小平滑标度。注意这一形状不是幂律，而是先上升后下降。优化学习得到的代理目标最终会损害真实目标。这是被量化的 Goodhart 峰。

可验证奖励的 RL。 推理模型使用的这一训练方案按趋于饱和的 sigmoid 曲线而非幂律标度。在迄今规模最大的系统研究中，性能作为 RL 计算量的函数可以预测，但采用的拟合包含渐近值、效率和中点；大多数方案选择改变效率而不改变渐近值 [45]。一个物理学式解释提示了形式为何不同，不过它是一个假说而非结果：预训练从有效无界的新结构 Zipf 尾部中挖掘，因此产生幂律；RL 后训练主要在有界任务分布上激发并重新加权基础模型已有的能力。用量子的语言说，预训练获得量子，而 RL 锐化已有量子上的策略，最终会耗尽它们。

测试时计算量是另一新轴：重复采样达到的覆盖率随样本数大致按幂律增长 [15]，训练时和测试时计算量可沿计算最优前沿相互交换 [82]。

目前尚不存在一个同时涵盖全部四种预算（预训练、SFT、RL、推理）的联合定律，也没有任何理论——哪怕达到量化模型这一层次——从数据和技能分布模型推导 sigmoid 或 Goodhart 峰。经验形式正等待统计力学处理。

我们希望，预训练理论综合中的每个组成部分——Gibbs 测度、核、平均场极限、MSRJD 作用量——都已作为从物理学引入的工具出现在本讲义中，这公平地概括了该领域的现状。标度律理论尚未完成，但可以辨认出它正在建立，并且由统计物理构成。后训练定律则更加年轻：其规律才刚刚开始确定，理论尚未建立。对于进入这一领域的学生，这是开放疆域从何处开始的一幅地图。

A 副本方法

第 2.3 节引入了淬火自由能 $-\mathbb{E}_{\text{data}} \log Z$ 和用 $-\log \mathbb{E}_{\text{data}} Z$ 代替它的退火近似 (2.18)；第 2.6 节使用该近似分析伊辛感知机。本附录解释如何通过副本方法精确计算淬火平均，以及退火近似漏掉了什么。

我们继续以第 2.6 节的伊辛感知机为贯穿全篇的例子，采用该节的记号和归一化：N 个二值权重 $\theta \in \{\pm 1\}^N$、二值教师 θ^*、高斯输入、$n = \alpha N$ 个样本和配分函数 (2.39)。这里所有内容的经典参考文献是 Engel 和 Van den Broeck[26]。

A.1 退火近似错在哪里

Jensen 不等式给出 $\log \mathbb{E} Z \geq \mathbb{E} \log Z$，所以退火自由能 $-\log \mathbb{E} Z$ 始终是淬火自由能的下界。要理解差距的来源，写出 $Z = e^{-N\varphi}$，其中自由能密度 φ 随数据集而涨落。指数化将 φ 的适度涨落变成 Z 的巨大涨落：某个数据集的 φ 比典型值低一个常数时，该数据集虽然指数罕见，但贡献的 Z 却指数地大；两个指数在 N 的同一阶上竞争。因而平均值 $\mathbb{E} Z$ 可能由概率趋于零的罕见数据集支配，而由 $\mathbb{E} \log Z$ 所描述的典型数据集行为不同。（这是对数正态随机变量的熟悉行为：其均值位于上尾深处。对于重尾量，均值并不是好的概括。）

对于伊辛感知机，误差的方向由此得到：支配 $\mathbb{E} Z$ 的数据集对学生的约束异常弱，而受到弱约束的学生位于低重叠处。因此退火平均高估了对齐不佳的学生所占权重，并高估学习所需的数据量：它把通向完美泛化的转变放在 $\alpha_c^{\text{ann}} \approx 1.45$，而下文概述的精确计算得到 $\alpha_c \approx 1.245$[35]。两者的转变结构相同，都是两个势盆交换主导地位。

备注。 退火近似并不总是错得这么温和。这里模型是可实现的（存在教师），且 φ 的涨落比较温和，所以退火只改变数值，不改变图景。一般而言，退火计算可能在定性上失败；最著名的是大负载下的离散权重模型，它可能预测负熵（少于一个相容的学生，对计数而言没有意义）和虚假的转变点。

A.2 副本

完整计算通过恒等式求 $\mathbb{E}_{\text{data}} \log Z$：

$$\mathbb{E} \log Z = \lim_{Q \to 0} \frac{\mathbb{E} Z^Q - 1}{Q} \qquad \big(\text{由} Z^Q = e^{Q \log Z} = 1 + Q \log Z + O(Q^2)\big). \tag{A.1}$$

策略是先对整数 Q 计算 $\mathbb{E} Z^Q$，此时它具有清楚含义，再得到关于 Q 的解析公式并将其延拓至 $Q \to 0$。对整数 Q，Z^Q 是学生的 Q 个独立副本（replicas）的配分函数，所有副本都由同一个数

据集评判。对于伊辛感知机，由式 (2.39)，

$$\mathbb{E}Z^Q = \frac{1}{2^{NQ}} \sum_{\theta^1,\dots,\theta^Q \in \{\pm 1\}^N} \mathbb{E}_{\text{data}} \prod_{\mu=1}^{n} \prod_{a=1}^{Q} \Theta\big(y^\mu(\theta^a \cdot x^\mu)\big). \tag{A.2}$$

数据平均很容易，因为输入是高斯的。固定副本和教师时，每个样本只通过 $Q+1$ 个数 $u^a = \theta^a \cdot x^\mu/\sqrt{N}$ 及 $v = \theta^* \cdot x^\mu/\sqrt{N}$ 进入计算；它们严格联合高斯（因为是 x^μ 的线性函数），均值为零，协方差完全由重叠矩阵

$$q^{ab} = \frac{\theta^a \cdot \theta^b}{N}, \qquad R^a = \frac{\theta^a \cdot \theta^*}{N}: \qquad \mathbb{E}[u^a u^b] = q^{ab}, \qquad \mathbb{E}[u^a v] = R^a, \qquad \mathbb{E}[v^2] = 1 \tag{A.3}$$

决定。阶跃函数的乘积要求每个 u^a 与 v 同号，这一事件的概率仅是重叠的某个函数 $e^{-e(q,R)}$：它是 $Q+1$ 维高斯正交域概率。由于样本独立，对 μ 上乘积的数据平均为其 n 次幂，即 $e^{-ne(q,R)} = e^{-\alpha N e(q,R)}$。$Q=1$ 时唯一重叠是 R，正交域为一个楔形，$e(R) = -\log(1-\epsilon(R))$ 是第 2.6 节的能量项。

无序消失了。取而代之，副本通过重叠 q^{ab} 相互耦合，而 Q 个二值向量的求和可按照重叠值组织，正如习题 2.3(c) 中按 R 组织单个二值向量的求和。将具有指定重叠的学生 Q 元组数量记为 $e^{Nh(q,R)}$（当 $Q=1$ 时，它是习题 2.3(c) 的二项式计数），并以积分代替对重叠的求和，

$$\mathbb{E}Z^Q \approx \int dq\, dR\, e^{-N s_Q(q,R)}, \qquad s_Q(q,R) := Q\log 2 - h(q,R) + \alpha e(q,R). \tag{A.4}$$

这是第 2.6 节单变量作用量 (2.44) 的副本版本，$Q=1$ 时退化为它。在大 N 下，积分由所有重叠中 s_Q 的最小值支配，副本恒等式 (A.1) 于是给出淬火自由能密度

$$\Phi(\alpha) := -\frac{1}{N}\mathbb{E}_{\text{data}} \log Z = \lim_{Q\to 0} \frac{1}{Q} \min_{q,R} s_Q(q,R). \tag{A.5}$$

与退火近似 $\min_R s_1(R)$ 比较：退火计算只保留一个副本，因此永远看不到共享数据诱导的副本间耦合 q^{ab}。这一耦合正是附录 A.1 发现所缺少的数据集间涨落信息。

副本对称性。 要具体使用式 (A.5)，需要把 h 和 e 表示为 $Q(Q+1)/2$ 个重叠的函数，并找到将结果延拓到 Q 的方式。标准假设是副本对称性：对所有 $a \neq b$ 取 $q^{ab} = q$，并取 $R^a = R$。这很自然，因为鞍点方程在交换副本时对称，并且问题因此缩减为两个标量。在此假设下，h 和 e 都成为一维高斯积分：正交域概率化简为对单一共享高斯“场”的高斯尾函数 $H(x) = \int_x^\infty \frac{dz}{\sqrt{2\pi}} e^{-z^2/2}$ 的积分；而对计数 h，通过为约束引入共轭变量，使其以第 2.4 节平均场伊辛模型的方式化为单格点问题。所得表达式关于 Q 解析，因此可在 $Q=0$ 求导。需要注意，对称的方程可以有不对称解，这在物理系统中确实发生，著名例子是自旋玻璃；因此必须检查这一假设，而对这里考虑的感知机问题，它成立。

结果。 副本对称计算 [35] 重现了伊辛感知机习题 2.3 的双势盆结构：一个内部解 $R^*(\alpha) < 1$，随数据积累向教师移动；另一个教师解 $R=1$；它们在一级相变处交换主导地位。改变的只是数值：从 $\alpha_c^{\text{ann}} \approx 1.45$ 变为 $\alpha_c \approx 1.245$。下面给出计算的引导式流程。

习题 A.1（通过副本进行淬火计算）。 请按兴趣允许的详略程度，对伊辛感知机完成以下程序；完整细节见 [26, 第 2、7 章]。

(a) *复制。*对整数 Q，如式 (A.2) 写出 $\mathbb{E}Z^Q$：系统的 Q 个副本仅通过共享数据耦合。

(b) *对数据取平均。*证明固定副本与教师时，$u^a=\theta^a\cdot x/\sqrt{N}$、$v=\theta^*\cdot x/\sqrt{N}$ 是精确的联合高斯变量，协方差为式 (A.3)；数据平均对各样本分解，每个样本贡献同一个重叠函数 $e^{-e(q,R)}$。检验 $Q=1$ 时 $e(R)=-\log(1-\epsilon(R))$，其中 ϵ 由楔形公式 (2.41) 给出。

(c) *推前到序参量。*插入固定 q^{ab} 和 R^a 的 delta 函数（以包含共轭变量 $\widehat{q}^{ab},\widehat{R}^a$ 的积分表示），使对二值向量的求和按格点 $i=1,\dots,N$ 分解并变为一个 Q 自旋和的 N 次幂。由此得出 $\mathbb{E}Z^Q$ 的形式 (A.4)，并表明退火作用量 (2.44) 是其 $Q=1$ 情形。

(d) *副本对称性。*对 $a\neq b$ 取 $q^{ab}=q$、$R^a=R$（共轭变量同样处理）。证明正交域概率变为 $e^{-e_{\mathrm{RS}}}=2\int Dt\,H(\cdot)^Q$，其中尾函数 H 的适当自变量由 q,R 和一个高斯变量 t 构成；格点求和变为 $(2\cosh(\cdot))^Q$ 的一维高斯积分。将两者关于 Q 延拓，并在 $Q=0$ 展开至一阶。

(e) *利用 Gibbs 学习的对称性。*从相容集合中均匀抽取的学生在统计上与教师无法区分，因为教师本身也是与数据相容的均匀随机二值向量。论证这迫使鞍点处 $q=R$：两个 Gibbs 学生之间的重叠等于它们与教师的重叠。于是仅剩一个标量及其一个共轭变量。

(f) *求解。*$R(\alpha)$ 的鞍点方程是超越方程。对其数值求解，证明存在两个竞争解：一个内部解和 $R=1$，它们的自由能在 $\alpha_c\approx 1.245$ 处交叉。与习题 2.3(g) 的退火结果 $\alpha_c^{\mathrm{ann}}\approx 1.45$ 比较，并用附录 A.1 解释移动的方向。

A.3 一种变体：球面感知机

在一个连续权重变体中，副本方法最容易一直推进到闭式结果；它也是退火与淬火学习曲线可以解析比较的经典情形。保持第 2.6 节其他设定不变，但令权重取实值 $\theta,\theta^*\in\mathbb{R}^N$。由于 $f_\theta=\mathrm{sign}(\theta\cdot x)$ 在 $\theta\to\lambda\theta$、$\lambda>0$ 下不变，可以通过把权重放在球面上去除冗余尺度：

$$|\theta|^2=|\theta^*|^2=N, \tag{A.6}$$

该归一化使各个权重保持 $O(1)$，先验取球面上的均匀测度 $\pi(\theta)\,d\theta$。这就是球面感知机。泛化误差的楔形公式 (2.41) 保持不变，因为它的推导只用到了 $(\theta\cdot x,\theta^*\cdot x)/\sqrt{N}$ 是相关系数为 R 的高斯变量对，而这一点对任何满足 $|\theta|^2=N$ 的 θ 都成立。

改变的是熵：重叠为 R 的学生数变成球面在重叠 R 处切片的体积。分解 $\theta=R\theta^*+\theta_\perp$，其中 $\theta_\perp\perp\theta^*$。约束 (A.6) 给出 $|\theta_\perp|^2=N(1-R^2)$，所以该切片是 $(N-1)$ 维正交补空间中半径为 $\sqrt{N(1-R^2)}$ 的球面，其体积正比于 $[N(1-R^2)]^{(N-2)/2}$，因此

$$\frac{1}{N}\log\int_{\theta:\,R(\theta)=R}d\theta\,\pi(\theta)=h(R)=\frac{1}{2}\log(1-R^2)+\text{常数}+O\!\left(\frac{1}{N}\log N\right). \tag{A.7}$$

用这一熵重复习题 2.3(d) 的退火计算，得到

$$\mathbb{E}_{\mathrm{data}}Z\approx\int_{-1}^{1}dR\,e^{-NS_{\mathrm{ann}}(R)},\qquad S_{\mathrm{ann}}(R):=\underbrace{-\frac{1}{2}\log(1-R^2)}_{\text{熵}}-\underbrace{\alpha\log\big(1-\epsilon(R)\big)}_{\text{能量}}, \tag{A.8}$$

退火自由能密度为

$$\Phi_{\text{ann}}(\alpha) := \min_R S_{\text{ann}}(R). \tag{A.9}$$

图 9 显示若干负载下的 S_{ann}。熵—能量竞争与伊辛感知机相同，但结果不同：当 $R \to 1$ 时熵项 $-\frac{1}{2}\log(1-R^2)$ 发散，所以完全对齐状态受到无限惩罚，极小点始终位于内部，并随着 α 增大从 $R=0$ 向 $R=1$ 连续移动。没有相变。这就是习题 2.3(h) 最后一个问题的答案：伊辛感知机的二值权重使对齐态具有有限熵 $h(1)=0$，这使它能够作为独立势盆参与竞争。

学习曲线。 大 α 行为可通过在 $R=1$ 附近展开得到。写 $R=\cos(\pi\epsilon)$，使 ϵ 本身就是泛化误差，则 $1-R^2 \approx (\pi\epsilon)^2$，并且

$$S_{\text{ann}} \approx -\log(\pi\epsilon) + \alpha\epsilon + \text{常数}, \tag{A.10}$$

其极小值位于

$$\epsilon_{\text{ann}}(\alpha) \simeq \frac{1}{\alpha}. \tag{A.11}$$

泛化误差随数据量按幂律衰减，指数为一：这是第 7 节标度律最简单的一个例子。精确的淬火处理 [77, 26] 沿习题 A.1 的副本步骤进行，以体积熵 (A.7) 代替计数（这里副本对称性可以通过与数据相容的球面区域的凸性证明），得到

$$\epsilon_{\text{Gibbs}}(\alpha) \simeq \frac{0.625}{\alpha}: \tag{A.12}$$

指数相同，常数不同。与附录 A.1 一样，退火平均给对齐较差的学生过高权重，高估误差，$1/\alpha > 0.625/\alpha$；而由于模型可实现，即使常数改变，指数仍保留。

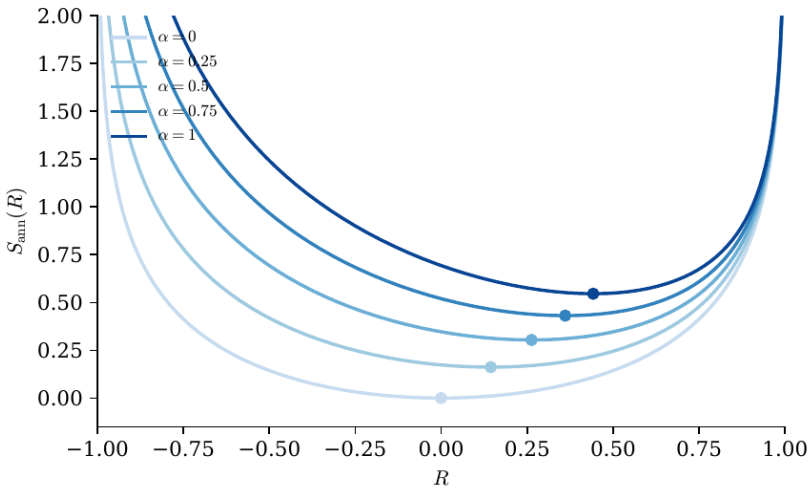


图 9: 球面感知机的退火作用量 $S_{\text{ann}}(R)$（式 (A.8)），取 $\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$（在 $R=0$ 处由下至上），每条曲线标出了极小点。当 $\alpha = 0$ 时熵将极小点固定在 $R=0$；负载增大使它平滑滑向更大重叠，而 $R=1$ 处的熵壁使它保持在内部。每个 α 都只有一个势盆，且连续移动：没有相变。

习题 A.2（球面感知机的退火学习曲线）。

(a) 推导切片熵 (A.7)，并重复习题 2.3(d) 的步骤构造退火作用量 (A.8)。

(b) 推导式 (A.9) 的鞍点条件，并表明 $R = 1$ 从不是极小点；与习题 2.3(f) 比较。

(c) 验证大 α 学习曲线 (A.11)，并证明小 α 时退火理论预测 $R \propto \alpha$。画出完整学习曲线 $\epsilon(\alpha)$ 的示意图。

(d) 习题 A.1 中哪些步骤在二值学生计数被体积 (A.7) 替代时改变，哪些不变?

B 从线性回归到核回归

本附录自成一体地回顾对参数呈线性的模型：线性回归、固定非线性特征上的回归、核回归和核岭回归。最后我们会看到，在初始化附近线性化的神经网络——第 4 节的假设形式 (4.1)——恰好是这类模型，因此训练它相当于核岭回归。这里不要求大宽度、梯度流渐近极限或变化的特征；它们是第 3–5 节的主题，而本附录提供其所依据的线性代数。如果读者觉得第 4.1 和 4.6 节中的核公式出现得突兀，可以先阅读本附录。[19]

使用第 3.1 节的记号：训练数据 $(x^\mu, y^\mu)_{\mu=1}^n$ 满足 $x^\mu \in \mathbb{R}^d$、$y^\mu \in \mathbb{R}$；模型 $f_\theta : \mathbb{R}^d \to \mathbb{R}$ 的参数为 $\theta \in \mathbb{R}^P$；$f^\mu := f_\theta(x^\mu)$ 为其在训练输入上的取值。将数据堆叠成矩阵很方便：

$$X := \begin{pmatrix} (x^1)^T \\ \vdots \\ (x^n)^T \end{pmatrix} \in \mathbb{R}^{n\times d}, \qquad Y := \begin{pmatrix} y^1 \\ \vdots \\ y^n \end{pmatrix} \in \mathbb{R}^n, \qquad f := \begin{pmatrix} f^1 \\ \vdots \\ f^n \end{pmatrix} \in \mathbb{R}^n. \tag{B.1}$$

因此 $X^\mu{}_j = x^\mu_j$ 是第 μ 个输入的第 j 个坐标，输入及其标签以相同方式堆叠。全文采用第 4.1.1 节的均方误差损失：

$$\mathcal{L}_\theta = \frac{1}{2}\sum_{\mu=1}^{n}(f^\mu - y^\mu)^2 = \frac{1}{2}|f - Y|^2 = \frac{1}{2}\delta_{\mu\nu}\Delta^\mu\Delta^\nu, \qquad \Delta^\mu := f^\mu - y^\mu, \tag{B.2}$$

其中 $\Delta \in \mathbb{R}^n$ 是残差。许多文献（包括本附录所依据的笔记）将损失归一化为 $\frac{1}{2n}|f - Y|^2$；这使下文的岭参数 λ 重标度一个因子 n，学习率 η 重标度一个因子 $1/n$，除此之外没有变化。

B.1 线性回归

最简单的模型对输入呈线性：

$$f_\theta(x) = \theta \cdot x = \sum_{j=1}^{d}\theta^j x_j, \qquad \theta \in \mathbb{R}^d, \tag{B.3}$$

因此 $P = d$，训练预测向量为 $f = X\theta$。（如下面习题所示，可以为每个输入添加常数坐标 $x_{d+1} = 1$，从而加入截距。）损失 $\mathcal{L}_\theta = \frac{1}{2}|X\theta - Y|^2$ 是关于 θ 的凸二次函数，其梯度为

$$\nabla_\theta \mathcal{L} = X^T(X\theta - Y) = X^T\Delta. \tag{B.4}$$

[19]本附录改编自 Charles Renshaw-Whitman 为 Iliad Intensive 准备的讲座与习题笔记，并改写为第 3.1 节的记号。

它具有本讲义中所有梯度的形式：Jacobian $\partial f^\mu/\partial\theta^j$ 的转置——此处为常数矩阵 X——作用于残差，参见式 (4.10)。令梯度为零得到*正规方程*

$$X^T X\,\theta = X^T Y. \tag{B.5}$$

由于损失是凸的，式 (B.5) 的每个解都是全局极小点，也没有其他临界点。解的形态取决于 $P = d$ 与 n 的大小关系。

参数少于数据，$P < n$。 若 X 的列线性无关——这是 $d \le n$ 时的典型情况——则 $X^T X$ 正定，因为 $v \neq 0$ 时 $v^T X^T X v = |Xv|^2 > 0$。此时存在唯一极小点：

$$\theta_* = (X^T X)^{-1} X^T Y. \tag{B.6}$$

正规方程表明残差 $\Delta_* = X\theta_* - Y$ 正交于 X 的每一列。等价地，预测 $X\theta_*$ 是 Y 在列空间 $\mathrm{col}(X) \subset \mathbb{R}^n$ 上的*正交投影*；该列空间是模型能够产生的所有预测向量组成的集合（图 10）。拟合就是投影。即便 θ_* 不唯一，投影 $X\theta_*$ 仍是唯一的。

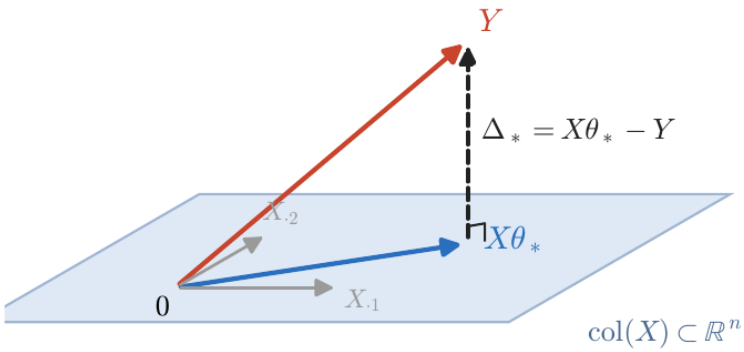


图 10: 最小二乘的几何表示。正规方程 $X^T\Delta_* = 0$ 表明残差正交于 X 的列空间，因此拟合预测向量 $X\theta_*$ 是 Y 在 $\mathrm{col}(X)$ 上的正交投影。这里的“正交”指训练集函数值空间 $\mathbb{R}^n$ 上的欧氏度量 $\delta_{\mu\nu}$。

值得停下来审视“正交”一词。最小二乘使 $X\theta$ 与 Y 之间的欧氏（L^2）距离最小化，投影相对于 $\mathbb{R}^n$ 上的欧氏度量 $\delta_{\mu\nu}$ 正交——这正是第 4.1.1 节中明确给出的函数值空间度量。这种度量是一种*选择*，隐藏在“均方误差”一词中：它规定给定大小的误差在每个数据点上的权重相同，而不同数据点的误差彼此独立。$\mathbb{R}^n$ 上任意其他正定度量 $g_{\mu\nu}$ 定义不同损失 $\mathcal{L}^g = \frac{1}{2} g_{\mu\nu}\Delta^\mu\Delta^\nu$，其极小点为

$$\theta^g_* = (X^T g X)^{-1} X^T g Y, \tag{B.7}$$

即 Y 在 $\mathrm{col}(X)$ 上关于 g 的正交投影（“加权最小二乘”）。除非 Y 已经位于 $\mathrm{col}(X)$ 中，不同度量会给出真正不同的拟合函数；见下文习题 B.1(d)。注意，$g_{\mu\nu}$ 是由数据点索引的函数值空间上的度量，而不是输入空间 $\mathbb{R}^d$ 上的度量。

参数多于数据，$P > n$。 若 $d > n$，或更一般地 X 的列线性相关，则 X^TX 奇异。正规方程仍有解（习题 B.1(b)），但此时解有无穷多个：它们构成 $\mathbb{R}^P$ 中维数为 $P - \operatorname{rank}(X)$ 的仿射子空间。如果 X 还有满行秩 n，那么 $Y \in \operatorname{col}(X)$，每个解都精确插值数据，即 $X\theta = Y$，损失为零。损失本身无法从这些解中作出选择；必须由别的东西来选择，这正是附录 B.3 的主题，也是核的来源。$P > n$ 远非特例，而是神经网络中的常态。

习题 B.1（手算最小二乘）。

(a) 对单个坐标 θ^j 求 $\mathcal{L}_\theta = \frac{1}{2}|X\theta - Y|^2$ 的导数，将各分量组合成式 (B.4)，并导出正规方程 (B.5)。从几何上解释为何它们表明残差正交于 X 的每一列。

(b) 证明若 X 列满秩，则 X^TX 正定，从而式 (B.6) 是唯一极小点。证明正规方程总是相容的（即 $X^TY \in \operatorname{col}(X^TX)$），而当 $P > n$ 时它有无穷多个解。

(c) 用仿射函数 $f(x) = \theta^1 + \theta^2 x$ 拟合三个点 $x \in \{-1, 0, 1\}$ 及标签 $y = x^2$，即取

$$X = \begin{pmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{pmatrix}, \qquad Y = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}.$$

求 θ_*、预测、残差及损失。剩余误差是优化失败还是表达能力不足？

(d) 对加权损失 (B.7)，取 $g = \operatorname{diag}(1, 4, 1)$，重复上一小题。这表示对中间数据点的信任程度是其他点的四倍。验证拟合函数发生变化。

B.2 使用非线性特征的线性回归

“线性模型”说明的是参数如何进入模型，而不是拟合函数的形状。在查看任何标签之前，选择一个特征映射

$$\psi : \mathbb{R}^d \to \mathbb{R}^P, \qquad \psi(x) = (\psi_1(x), \dots, \psi_P(x)), \tag{B.8}$$

并考虑模型

$$f_\theta(x) = \theta \cdot \psi(x) = \sum_{i=1}^{P} \theta^i \psi_i(x), \qquad \theta \in \mathbb{R}^P. \tag{B.9}$$

这是 P 个固定形状 ψ_i 的加权和。它对 x 可以像这些形状本身那样非线性，但对 θ 是线性的。常见选择包括输入坐标中至多 m 次的单项式（此时 $P = \binom{d+m}{m}$）、Fourier 模式、以所选点 c_k 为中心的高斯凸起 $e^{-|x-c_k|^2/2\sigma^2}$，以及随机特征 $\psi_i(x) = \phi(a_i \cdot x)$，其中 a_i 随机抽取后固定。最后一种是第一层从不训练的单隐藏层网络。

将训练输入的特征向量堆叠为 $n \times P$ 的特征矩阵

$$\Psi^\mu{}_i := \psi_i(x^\mu), \tag{B.10}$$

则训练预测为 $f = \Psi\theta$。注意 $\Psi^\mu{}_i = \partial f^\mu / \partial \theta^i$：特征矩阵正是第 4.2 节的 Jacobian J，对线性模型而言它是常数。线性回归是 $\psi(x) = x$、$\Psi = X$ 的特例；附录 B.1 的一切结论都可原样适用，只需将

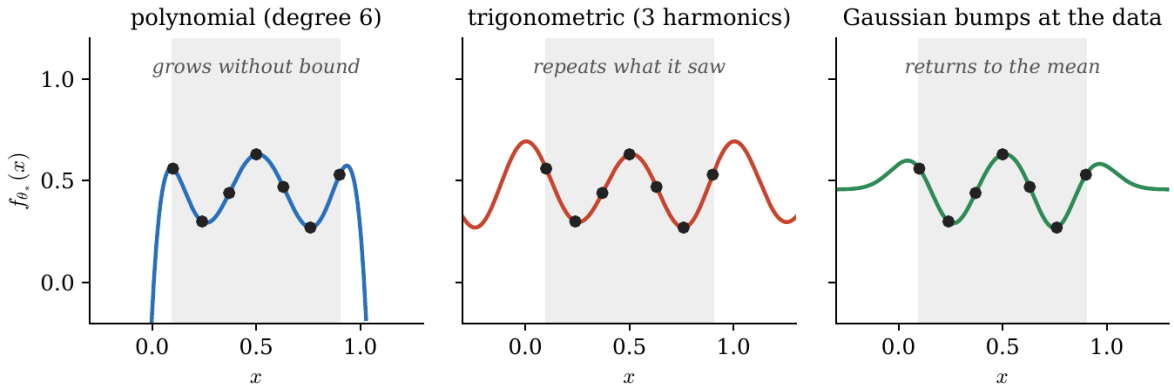


图 11: 选择 ψ 就是在选择模型。同样的七个数据点（黑色），由三种不同的固定特征映射精确插值，均取 $P = n = 7$：六次多项式、周期为一且含三个谐波的三角函数，以及以数据为中心的高斯凸起。三者都使训练损失为零，却在训练范围（阴影）之外处处不一致；这种差异在读取标签之前就已经确定。图中依次标示“无界增长”“重复所见”和“回到均值”。

X 换成 Ψ：正规方程为 $\Psi^T\Psi\theta = \Psi^T Y$；若 $P \le n$ 且 Ψ 列满秩，唯一极小点为 $\theta_* = (\Psi^T\Psi)^{-1}\Psi^T Y$；若 $P > n$，则有无穷多个插值解。

将 X 换成 Ψ 丝毫没有改变代数过程，却彻底改变了模型。图 11 展示了同样七个点上拟合出的三种特征映射，每种都取 $P = n$。它们各自精确插值数据，却在其他位置给出不同结果。哪一个正确？数据无法回答：训练集以外的行为由 ψ 的选择决定，而该选择发生在读取标签之前。特征映射将模型的*归纳偏置*明确地呈现出来。

为什么要取很大的 P？图 12 给出了经典答案。平面上位于同心圆环的两类点无法用一条直线分开。添加一个固定特征 $\psi(u, v) = (u, v, c(u^2 + v^2))$，两类点就能在 $\mathbb{R}^3$ 中用一个平面分开：在提升坐标中线性的模型，在原坐标中是一个圆。代价是 P 增长很快。在 $d = 1000$ 个输入坐标中，仅三次单项式就有 $P = \binom{1002}{3} \approx 1.7 \times 10^8$ 个；以连续体上每个点为中心的高斯凸起则给出 $P = \infty$。然而数据点只有 n 个，拟合由 n 个数确定。问题本身并不要求求一个 $P \times P$ 矩阵的逆——那么 P 究竟在哪里进入计算？接下来两节将认真回答这个问题。

习题 B.2（三点特征计算）。 取习题 B.1(c) 中相同的三个点 $x \in \{-1, 0, 1\}$ 及标签 $y = x^2$，但令特征映射为 $\psi(x) = (1, \sqrt{2}\,x, x^2)$。

(a) 写出特征矩阵 Ψ，并求出精确插值全部三个标签的系数 θ。习题 B.1(c) 中表达能力不足的问题消失了：发生了什么变化？

(b) 准确解释为何预测器可以对 x 非线性，而回归问题仍然是线性的。

(c) 若将最后一个特征换成 cx^2，其中 $c \neq 0$，那么拟合函数、相应系数，还是二者都会变化？

(d) 不使用向量记号，写出内积 $K(x, z) := \psi(x) \cdot \psi(z)$ 的封闭形式。这是对附录 B.3 的预览。

B.3 核回归

回到过参数化的情形 $P > n$，并假设 Ψ 具有满行秩 n（这是典型情况），因此存在一个维数为 $P - n$ 的精确插值解仿射族 $\Psi\theta = Y$。为了选择其中一个，我们需要损失函数本身未提供的准

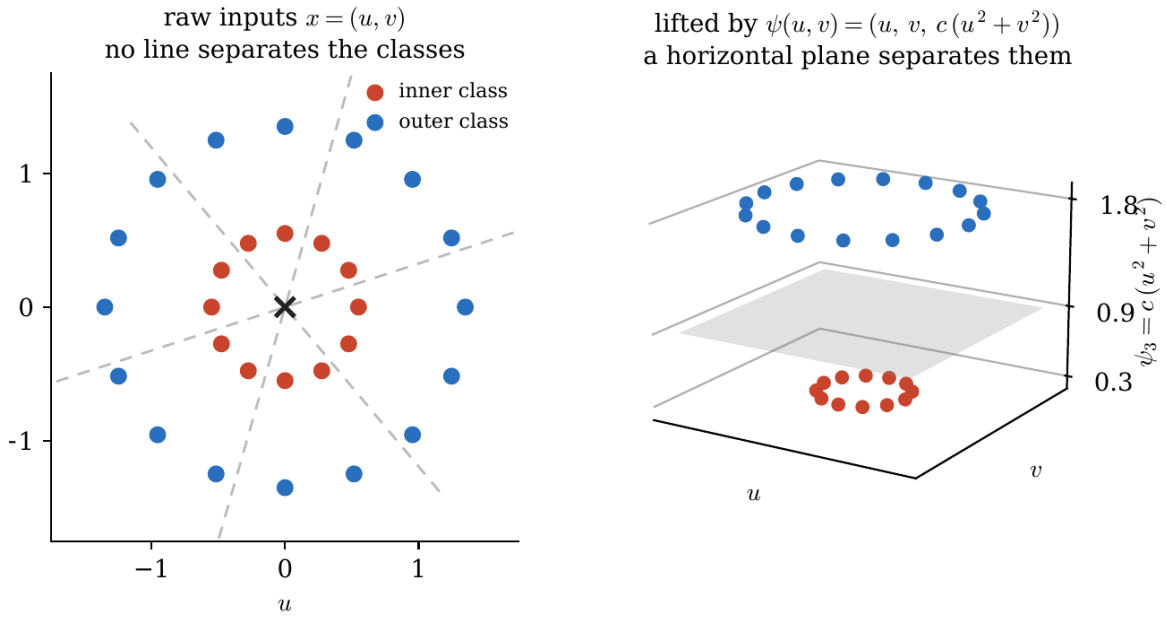


图 12: 一个固定的额外特征可以使困难问题变为线性问题。左：平面内同心圆环上的两类点。每类点的凸包都包含原点，因而没有直线可以将它们分开。右：添加单一特征 $\psi_3 = c(u^2+v^2)$ 后，两个圆环处于不同高度，一个水平平面 $\psi_3 = cr_0^2$ 即可将它们分开。这里没有学习任何东西：径向坐标是我们提供的。图中“inner class / outer class”分别指内圈类和外圈类。

则。标准选择是最小范数插值解：

$$\theta_* := \arg\min_{\Psi\theta = Y} |\theta|^2. \tag{B.11}$$

这里引入了第二个隐含的欧氏度量——这次是参数空间 $\mathbb{R}^P$ 上的 δ_{ij}，它也定义了第 4.1.1 节的梯度下降。（附录 B.1 使用的是函数值空间 $\mathbb{R}^n$ 上的 $\delta_{\mu\nu}$。）这两个度量发挥对偶作用：前者决定数据不能精确匹配时如何拟合，后者决定能够精确匹配时选取哪个拟合。

为求解式 (B.11)，给 n 个约束引入 Lagrange 乘子 $\alpha \in \mathbb{R}^n$，并对 $\frac{1}{2}|\theta|^2 - \alpha \cdot (\Psi\theta - Y)$ 求极值。关于 θ 的驻值条件给出

$$\theta_* = \Psi^T \alpha = \sum_{\mu=1}^{n} \alpha_\mu \psi(x^\mu). \tag{B.12}$$

这是关键结构事实：无论 P 有多大，最小范数解都位于训练输入的特征向量所张成的 $\mathbb{R}^P$ 的 n 维子空间中，由 n 个数描述。（用第 4.2 节的语言说，θ_* 位于 Jacobian 的行空间中。）于是约束 $\Psi\theta_* = Y$ 变为 $\Psi\Psi^T\alpha = Y$，这是一个 $n \times n$ 的线性系统。定义核及其在训练集上的 Gram 矩阵：

$$\begin{aligned} K(x,x') &:= \psi(x)\cdot\psi(x') = \sum_{i=1}^{P} \psi_i(x)\psi_i(x'), \\ \widehat{K}^{\mu\nu} &:= K(x^\mu, x^\nu) = (\Psi\Psi^T)^{\mu\nu}. \end{aligned} \tag{B.13}$$

核是特征向量的内积：一旦 ψ 固定，它定义一种不涉及标签的输入相似性。Gram 矩阵对称且半正定，因为 $c^T\widehat{K}c = |\Psi^T c|^2 \geq 0$；它恰在 Ψ 行满秩时正定，这也是我们的假设。于是 $\alpha = \widehat{K}^{-1}Y$，

任意输入 x 处的预测为

$$f_*(x) = \theta_* \cdot \psi(x) = \sum_{\mu=1}^{n} \alpha_\mu K(x, x^\mu) = \sum_{\mu,\nu=1}^{n} K(x, x^\mu) \widehat{K}^{-1}_{\mu\nu} y^\nu. \tag{B.14}$$

这就是核回归（更准确地说是核插值）。特征映射已经从拟合和预测的表达式中消失。拟合只需训练点两两之间的 K；预测只需测试点与训练点之间的 K；从不需要构造特征向量。预测是与训练点相似性的加权和，权重 α 依赖标签——但标签只对训练点重新加权，从不改变 K 认为哪些输入相似。

将式 (B.14) 与惰性训练网络的长时均值式 (4.38) 比较，可见二者形式相同，只是用 $\widehat{K}$ 代替 NTK。这并非巧合。对于任何对参数呈线性的模型，Jacobian $J = \Psi$，所以 NTK 为

$$\Theta^{\mu\nu} = (JJ^T)^{\mu\nu} = \widehat{K}^{\mu\nu}, \tag{B.15}$$

它不随时间变化。此外，梯度流找到最小范数解：$\dot{\theta} = -\eta \Psi^T \Delta$ 始终沿着 Ψ 的行空间，所以 $\theta(t) - \theta_0$ 保持在该 n 维子空间内，并收敛到距离 θ_0 最近的插值解；当 $\theta_0 = 0$ 时即为 θ_*（习题 B.3(c)）。这是梯度下降隐式偏置的最简单例子，也体现了参数空间的欧氏度量从另一条路径进入问题：流由 δ^{ij} 定义，它最终最小化的范数亦然。

核技巧。 式 (B.14) 有两种读法。从特征侧看，它把一个 $P \times P$ 问题改写为 $n \times n$ 问题；从核侧看，它表明特征映射可以省去：任何能够写成特征内积的函数 $K(x, x')$ 都可使用，无论能否写出这些特征。对 $x, z \in \mathbb{R}^2$ 和 $\psi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$，可以验证 $\psi(x) \cdot \psi(z) = (x \cdot z)^2$：一个内积的平方便代表了三个特征。在 d 维中，$K(x, z) = (x \cdot z)^m$ 的计算成本是 $O(d)$，却代表全部 $\binom{d+m-1}{m}$ 个 m 次单项式。高斯核 $K(x, z) = e^{-|x-z|^2/2\sigma^2}$ 对应一个通常不会明确写出的无限维特征映射。反过来，任何所有 Gram 矩阵都半正定的对称核 K 都来自某种特征映射（Mercer 定理）：K 的特征函数乘以相应特征值的平方根，便给出其中一个映射（参见第 3.3 和 4.6 节）。这是一种权衡而非免费午餐：特征途径随 P 扩展，核途径随 n 扩展；样本很多而特征很少时，显式途径更便宜。

习题 B.3（最小范数插值与核）。

(a) 完成导出式 (B.12)–(B.14) 的 Lagrange 乘子计算。或者使用第 4.2 节的奇异值分解 $\Psi = USV^T$，证明最小范数插值解为 $\theta_* = \Psi^T(\Psi\Psi^T)^{-1}Y$，并用 U, S, V 表示它。

(b) 对所有 $c \in \mathbb{R}^n$ 证明 $c^T \widehat{K} c = |\Psi^T c|^2 \geq 0$。将 $\widehat{K}$ 的零特征值解释为特征空间中消失的训练样本线性组合。$\widehat{K}$ 可逆需要什么条件？

(c) 证明在梯度流 $\dot{\theta} = -\eta \Psi^T(\Psi\theta - Y)$ 下，位移 $\theta(t) - \theta_0$ 对任意 t 均保持在 Ψ 的行空间中；导出 $\Delta(t) = e^{-\eta t \widehat{K}} \Delta(0)$；由此说明当 $\widehat{K}$ 可逆时，流收敛到最接近 θ_0 的插值解。对该模型取 $\Theta = \widehat{K}$，导出式 (4.36)。

(d) 对 $\psi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ 验证 $\psi(x) \cdot \psi(z) = (x \cdot z)^2$，并解释 $\sqrt{2}$ 为何不是装饰。$\mathbb{R}$ 上哪个特征映射给出习题 B.2(d) 中的核 $(1 + xz)^2$？$\mathbb{R}^d$ 上 $(x \cdot z)^m$ 代表多少个特征？

B.4 核岭回归

除了将最小范数准则作为硬约束，还可以把它作为惩罚项加入损失。对 $\lambda > 0$，岭回归最小化

$$\mathcal{L}_\lambda(\theta) := \frac{1}{2}|\Psi\theta - Y|^2 + \frac{\lambda}{2}|\theta|^2. \tag{B.16}$$

两项分别用 $\delta_{\mu\nu}$ 衡量与数据的距离、用 δ_{ij} 衡量与原点的距离：岭回归是附录 B.1 和 B.3 两个度量之间的加权折中，λ 设定其交换比例。（在神经网络训练中，这个惩罚称为权重衰减。）惩罚同时完成两件事：当 $P > n$ 时，它从无穷多个解中选出一个；无论 P 多大，它都使问题适定，即使特征冗余或标签有噪声。注意该惩罚在特征重标度下并不不变：它在给定的 ψ 坐标下决定何谓“大”系数。

梯度为 $\Psi^T(\Psi\theta - Y) + \lambda\theta$，所以驻值条件为

$$(\Psi^T\Psi + \lambda I_P)\theta = \Psi^T Y. \tag{B.17}$$

对任意 $\lambda > 0$，无论 Ψ 的秩如何，左边矩阵均正定，因为 $v \neq 0$ 时 $v^T(\Psi^T\Psi+\lambda I_P)v = |\Psi v|^2+\lambda|v|^2 > 0$。因此总存在唯一极小点：

$$\theta_\lambda = (\Psi^T\Psi + \lambda I_P)^{-1}\Psi^T Y, \tag{B.18}$$

但代价是求一个 $P \times P$ 逆矩阵。为把求逆转移到 $n \times n$ 侧，展开并重排乘积：

$$\Psi^T(\Psi\Psi^T + \lambda I_n) = \Psi^T\Psi\Psi^T + \lambda\Psi^T = (\Psi^T\Psi + \lambda I_P)\Psi^T. \tag{B.19}$$

两个括号内的矩阵均正定，所以在适当侧乘其逆可得推移恒等式

$$(\Psi^T\Psi + \lambda I_P)^{-1}\Psi^T = \Psi^T(\Psi\Psi^T + \lambda I_n)^{-1}. \tag{B.20}$$

这里没有约掉任何东西。Ψ^T 是矩形矩阵，没有逆，这正是该恒等式成立的原因。代入式 (B.18)，岭回归解再次位于训练特征向量的张成空间内，$\theta_\lambda = \Psi^T\alpha_\lambda$，其中 $\alpha_\lambda = (\widehat{K} + \lambda I_n)^{-1}Y$；新输入的预测为

$$f_\lambda(x) = \sum_{\mu,\nu=1}^{n} K(x, x^\mu)(\widehat{K} + \lambda I_n)^{-1}_{\mu\nu} y^\nu. \tag{B.21}$$

这就是核岭回归，也是本附录的核心公式。当 $\lambda \to 0$ 时，若 $\widehat{K}$ 可逆，它化为最小范数插值解 (B.14)；一般情况下则化为最小范数最小二乘解（习题 B.4(c)）。当 $\lambda \to \infty$，$\theta_\lambda \to 0$。

式 (B.21) 正是习题 4.5 的后验均值，岭参数为 $\lambda = \beta^{-1}$：那边是对无限宽高斯过程导出的，这里则针对有限线性模型。贝叶斯解释值得明确写出：取高斯似然 $\propto e^{-\frac{\beta}{2}|\Psi\theta-Y|^2}$ 和高斯先验 $\theta \sim \mathcal{N}(0, \sigma^2 I_P)$，当 $\lambda = 1/(\beta\sigma^2)$ 时，损失 (B.16) 就是后验密度对数乘以 $-\beta^{-1}$ 后加一个常数。因此岭回归是最大后验估计。将先验推前到 $f_\theta(x) = \theta \cdot \psi(x)$，得到以 $\sigma^2 K(x, x')$ 为核的高斯过程，这是第 3.3 节的有限 P 例子；习题 4.5 对该过程给出的后验均值重现式 (B.21)。

谱视角。 利用第 4.2 节的奇异值分解 $\Psi = USV^T$，Gram 矩阵为 $\widehat{K} = US^2U^T$，其特征值为 s_a^2，对应标准正交特征向量 $u_a \in \mathbb{R}^n$：它们就是第 4.2 节的“特征”，即函数值空间的自然模式。训练集上的岭预测为 $f_\lambda = \Psi\theta_\lambda = \widehat{K}(\widehat{K} + \lambda I_n)^{-1}Y$，逐模式写成

$$f_\lambda = \sum_a \frac{s_a^2}{s_a^2 + \lambda}(u_a \cdot Y)u_a. \tag{B.22}$$

岭回归是谱滤波器：数据中 $s_a^2 \gg \lambda$ 的模式得到拟合，$s_a^2 \ll \lambda$ 的模式被抑制，过渡发生在 $s_a^2 \approx \lambda$。与之比较，对无惩罚损失从 $\theta_0 = 0$ 开始的梯度流，其训练预测由式 (4.35) 为

$$f(t) = \sum_a (1 - e^{-\eta t s_a^2})(u_a \cdot Y)u_a. \tag{B.23}$$

这也是谱滤波器，其中 $1/(\eta t)$ 扮演 λ 的角色：提前停止的正则化作用与岭回归相似。但两个滤波器的形状不同（图 13），对一个给定停止时刻，不存在一个 λ 能同时在每个模式上重现该结果（习题 B.5）。这就是第 4.6 节末尾所说贝叶斯学习的逆温度与梯度下降训练时间具有类似作用的准确含义。

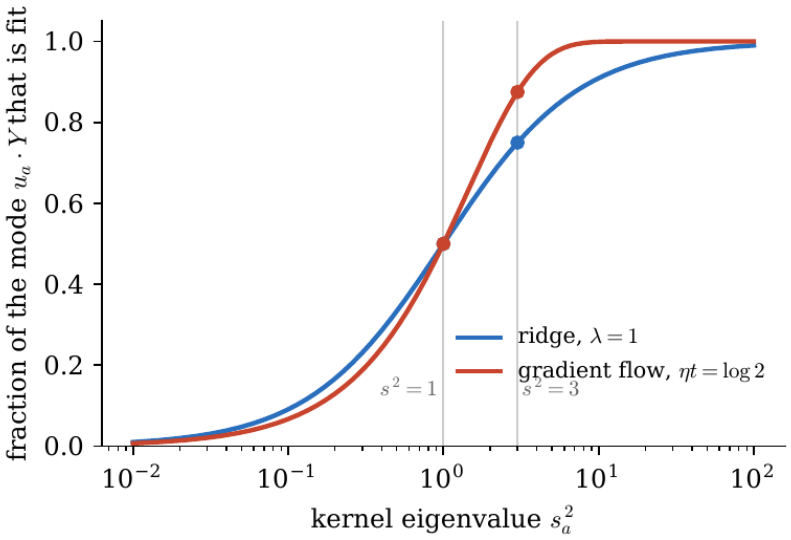


图 13: 作为谱滤波器的岭回归与提前停止梯度流：横轴为模式核特征值 s_a^2，纵轴为被拟合的数据模式 $u_a \cdot Y$ 的比例。两个滤波器被调节成在 $s^2 = 1$ 的模式上一致，在其他位置不同；图中点标出习题 B.5 的双模式例子。蓝线为岭回归 $\lambda = 1$，红线为梯度流 $\eta t = \log 2$。

习题 B.4（两种途径的岭回归）。

(a) 导出式 (B.17) 和 (B.18)，并证明即使 Ψ 秩亏，$\Psi^T\Psi + \lambda I_P$ 仍可逆。

(b) 证明推移恒等式 (B.20) 并导出式 (B.21)。解释为什么“约掉 Ψ^T”不是有效步骤，以及为什么恒等式仍然成立。（它是 $A(BA + I)^{-1} = (AB + I)^{-1}A$ 的一个特例。）

(c) 当 $\lambda \to \infty$ 会怎样？利用 SVD 证明 θ_λ 对 Ψ 的每个奇异值 s 施加标量滤波器 $s/(s^2 + \lambda)$，由此说明当 $\lambda \to 0$，它收敛到最小范数的最小二乘解。该极限何时精确插值标签？

(d) 回到习题 B.2 的 $x \in \{-1, 0, 1\}$、$y = x^2$ 和核 $K(x, z) = (1 + xz)^2$。取 $\lambda = 1$，验证

$$\widehat{K} = \begin{pmatrix} 4 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 4 \end{pmatrix}, \qquad \alpha_\lambda = \frac{1}{4}\begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix},$$

并只用核函数计算来预测 $z = 2$ 处的值。与习题 B.2(a) 的插值函数在该处预测 $z^2 = 4$ 比较，并解释差异的方向。

(e) 特征途径要求解 $P \times P$ 系统，而核途径要求解 $n \times n$ 系统。各自在何时具有吸引力?

习题 B.5（两个数据点上的提前停止与岭回归）。 取 $n = 2$ 个训练点，其 Gram 矩阵和标签为

$$\widehat{K} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \qquad Y = \begin{pmatrix} 2 \\ 0 \end{pmatrix},$$

且初始预测 $f(0) = 0$。

(a) 验证特征对 $u_\pm = \frac{1}{\sqrt{2}}(1, \pm 1)^T$、$s_\pm^2 = 3, 1$，并将 Y 分解为这些模式。

(b) 利用式 (B.23) 求梯度流下的训练预测 $f(t)$，并在 $\eta t = \log 2$ 时求值。为何特征值 s_a^2 和初始投影 $u_a \cdot Y$ 都会影响训练期间可见的内容?

(c) 利用式 (B.22) 求 $\lambda = 1$ 时的岭预测。两个滤波器在 $s^2 = 1$ 模式上一致；证明对特征值 s^2 的模式，在时刻 t 与梯度流匹配的岭参数为 $\lambda_{\text{eff}}(s^2, t) = s^2/(e^{\eta t s^2} - 1)$，它依赖于模式——因此提前停止不是岭回归。

(d) 准确说明这一有限、固定核计算中“谱偏置”的含义。若要将它变成关于 Fourier 频率、对标签噪声的稳健性或测试误差的结论，还需要什么额外结构?

B.5 线性化网络是核岭回归模型

现在令 f_θ 为神经网络，$\theta \in \mathbb{R}^P$ 是其所有权重与偏置组成的向量。它对 θ 并不线性，但在初始化 θ_0 附近的线性化，即式 (4.1) 的假设形式，

$$f_\theta^{\text{lin}}(x) = f_{\theta_0}(x) + (\theta - \theta_0) \cdot \nabla_\theta f_{\theta_0}(x), \tag{B.24}$$

是式 (B.9) 形式的模型。逐项比较：参数是位移 $\delta\theta := \theta - \theta_0 \in \mathbb{R}^P$，特征映射是

$$\psi(x) = \nabla_\theta f_{\theta_0}(x) \in \mathbb{R}^P, \tag{B.25}$$

即*切线特征*：每个参数对应一个数，表示输入 x 处输出对该参数的敏感性，在初始化处计算后固定。常数偏移 $f_{\theta_0}(x)$ 则通过将标签平移为下式吸收：

$$\widetilde{y}^\mu := y^\mu - f_{\theta_0}(x^\mu) = -\Delta^\mu(0). \tag{B.26}$$

这个偏移很重要：线性化模型拟合的是初始化时的残差，而不是原始标签。式 (B.10) 的特征矩阵是初始化时的 Jacobian，$\Psi = J_0$；式 (B.13) 的 Gram 矩阵为

$$\widehat{K} = J_0 J_0^T = \Theta_0, \qquad K(x, x') = \Theta(x, x') = \nabla_\theta f_{\theta_0}(x) \cdot \nabla_\theta f_{\theta_0}(x'), \tag{B.27}$$

即初始化时的神经切线核 (4.10)，并按习题 4.3 扩展到任意输入对。附录 B.3 和 B.4 的所有内容现在都能原样使用。特别地，对线性化网络做岭回归并取惩罚 $\frac{\lambda}{2}|\theta-\theta_0|^2$——即向初始化点作权重衰减——由式 (B.21) 得到

$$f_\lambda^{\mathrm{lin}}(x) = f_{\theta_0}(x) - \sum_{\mu,\nu=1}^{n} \Theta(x, x^\mu)(\Theta_0 + \lambda I_n)^{-1}_{\mu\nu}\Delta^\nu(0). \tag{B.28}$$

当 $\lambda \to 0$，它是式 (4.36) 的 $t \to \infty$ 极限，即残差的最小范数插值解；有限时间解 (4.36) 则是其提前停止的近亲，其关系如式 (B.23) 所示。这里核技巧不是方便与否的问题，而是必要的：P 是网络的参数数目，通常达到 10^7 或更多，而 Θ_0 是 $n \times n$ 矩阵。

关于上述结论的范围，需要作两点说明。首先，对于线性化模型 f^{lin}，上述全部结果都是精确的，其核按构造保持不变。对于实际网络，式 (B.24) 是一个假设形式。第 4.3 节表明，在深度和数据固定的大宽度极限下它成为精确结果；在其他情形下它是否以及何时是良好近似，以及切线特征变化时会发生什么，是第 5–6 节而非本附录的主题。其次，初始化 θ_0 是随机的，所以 f_{θ_0}、切线特征和核 Θ_0 也都是随机的；式 (B.28) 是一次抽样得到的训练后函数。在 Θ_0 变为确定性的宽度极限下对抽样取平均，得到高斯过程 (4.38)。

习题 B.6（单隐藏层网络的切线特征）。 考虑 $f_\theta(x) = \sum_{i=1}^{N} c_i\phi(a_i \cdot x)$，其中 $\theta = (c_i, a_i)_{i=1}^{N}$，故 $P = N(d+1)$。

(a) 计算切线特征 $\nabla_\theta f_{\theta_0}(x)$，并证明切线核为

$$\Theta(x, x') = \sum_{i=1}^{N} \phi(a_i \cdot x)\phi(a_i \cdot x') + \sum_{i=1}^{N} c_i^2 \phi'(a_i \cdot x)\phi'(a_i \cdot x')(x \cdot x').$$

(b) 假设仅训练输出权重 c，而将 a_i 固定为它们的随机初始值。证明这恰好是式 (B.9) 的随机固定特征模型，其线性化是精确的，且其核是上式第一项。若只训练 a_i，得到哪一项?

(c) 证明，对于每个 $\lambda > 0$、从任意初始点出发，将带有朝初始化点权重衰减的梯度流 $\dot\theta = -\eta[\nabla_\theta \mathcal{L} + \lambda(\theta - \theta_0)]$ 应用于线性化模型 f^{lin}，都会收敛到岭解 (B.28)。

(d) 验证当 $\lambda \to 0$ 时，式 (B.28) 与 $t \to \infty$ 时的式 (4.36) 一致。

C 习题解答

原文此处说明，按习题出现顺序提供详细解答；教师可以通过取消前言中 `\solutionsfalse` 的注释来移除本附录内容及其他解答框。

译注： 当前所用的原文 PDF 为不含解答的版本（nosol），此附录未提供实际习题解答。译稿未补写缺失的解答。

参考文献

[1] Elisabeth Agoritsas, Giulio Biroli, Pierfrancesco Urbani, and Francesco Zamponi. Out-of-equilibrium dynamical mean-field equations for the perceptron model. *Journal of Physics A: Mathematical and Theoretical*, 51(8):085002, 2018. arXiv:1710.04894.

[2] Alexander Altland and Ben D. Simons. *Condensed Matter Field Theory*. Cambridge University Press, Cambridge, 2 edition, 2010.

[3] Daniel J. Amit, Hanoch Gutfreund, and H. Sompolinsky. Spin-glass models of neural networks. *Physical Review A*, 32(2):1007–1018, August 1985.

[4] Alexander Atanasov, Blake Bordelon, and Cengiz Pehlevan. Neural networks as kernel learners: the silent alignment effect. In *International Conference on Learning Representations (ICLR)*, 2022. arXiv:2111.00034.

[5] Yasaman Bahri, Ethan Dyer, Jared Kaplan, Jaehoon Lee, and Utkarsh Sharma. Explaining neural scaling laws. *Proceedings of the National Academy of Sciences*, 121(27):e2311878121, 2024. arXiv:2102.06701.

[6] Yasaman Bahri, Jonathan Kadmon, Jeffrey Pennington, Samuel S. Schoenholz, Jascha Sohl-Dickstein, and Surya Ganguli. Statistical mechanics of deep learning. *Annual Review of Condensed Matter Physics*, 11:501–528, 2020.

[7] Jürgen Berges. Introduction to Nonequilibrium Quantum Field Theory. *AIP Conference Proceedings*, 739(1):3–62, December 2004.

[8] Emmy Blumenthal. Building Intuition for Dynamical Mean-Field Theory: A Simple Model and the Cavity Method, July 2025.

[9] Blake Bordelon, Alexander Atanasov, and Cengiz Pehlevan. A dynamical model of neural scaling laws. In *International Conference on Machine Learning (ICML)*, 2024. arXiv:2402.01092.

[10] Blake Bordelon, Abdulkadir Canatar, and Cengiz Pehlevan. Spectrum dependent learning curves in kernel regression and wide neural networks. In *International Conference on Machine Learning (ICML)*, 2020. arXiv:2002.02561.

[11] Blake Bordelon, Lorenzo Noci, Mufan Bill Li, Boris Hanin, and Cengiz Pehlevan. Depthwise Hyperparameter Transfer in Residual Networks: Dynamics and Scaling Limit, December 2023.

[12] Blake Bordelon and Cengiz Pehlevan. Self-consistent dynamical field theory of kernel evolution in wide neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2205.09653.

[13] Blake Bordelon and Cengiz Pehlevan. Dynamics of Finite Width Kernel and Prediction Fluctuations in Mean Field Neural Networks, November 2023.

[14] Ari Brill. Neural scaling laws rooted in the data distribution, 2024. arXiv:2412.07942.

[15] Bradley Brown, Jordan Juravsky, Ryan Ehrlich, Ronald Clark, Quoc V. Le, Christopher Ré, and Azalia Mirhoseini. Large language monkeys: scaling inference compute with repeated sampling, 2024. arXiv:2407.21787.

[16] Abdulkadir Canatar, Blake Bordelon, and Cengiz Pehlevan. Spectral bias and task-model alignment explain generalization in kernel regression and infinitely wide neural networks. *Nature Communications*, 12:2914, 2021.

[17] Michael Celentano, Chen Cheng, and Andrea Montanari. The high-dimensional asymptotics of first order methods with random data, 2021. arXiv:2112.07572.

[18] Zhongtian Chen, Edmund Lau, Jake Mendel, Susan Wei, and Daniel Murfet. Dynamical versus bayesian phase transitions in a toy model of superposition. *arXiv preprint arXiv:2310.06301*, 2023.

[19] Lénaïc Chizat and Francis Bach. On the global convergence of gradient descent for over-parameterized models using optimal transport. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1805.09545.

[20] Lénaïc Chizat, Edouard Oyallon, and Francis Bach. On lazy training in differentiable programming. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. arXiv:1812.07956.

[21] Youngmin Cho and Lawrence K. Saul. Kernel methods for deep learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2009.

[22] Carson C. Chow and Michael A. Buice. Path Integral Methods for Stochastic Differential Equations, October 2012.

[23] Leticia F. Cugliandolo. Recent Applications of Dynamical Mean-Field Methods, May 2023.

[24] Simon S. Du, Xiyu Zhai, Barnabás Póczos, and Aarti Singh. Gradient descent provably optimizes over-parameterized neural networks. In *International Conference on Learning Representations (ICLR)*, 2019.

[25] Nelson Elhage, Tristan Hume, Catherine Olsson, Nicholas Schiefer, Tom Henighan, Shauna Kravec, Zac Hatfield-Dodds, Robert Lasenby, Dawn Drain, Carol Chen, Roger Grosse, Sam McCandlish, Jared Kaplan, Dario Amodei, Martin Wattenberg, and Christopher Olah. Toy models of superposition. *arXiv preprint arXiv:2209.10652*, 2022.

[26] Andreas Engel and Christian Van den Broeck. *Statistical Mechanics of Learning*. Cambridge University Press, 2001.

[27] Zhou Fan, Justin Ko, Bruno Loureiro, Yue M. Lu, and Yandi Shen. Dynamical mean-field analysis of adaptive Langevin diffusions: propagation-of-chaos and convergence of the linear response, 2025. arXiv:2504.15556.

[28] Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In *International Conference on Machine Learning (ICML)*, 2023. arXiv:2210.10760.

[29] Crispin W. Gardiner. *Handbook of Stochastic Methods: for Physics, Chemistry and the Natural Sciences*. Springer, 3 edition, 2004.

[30] Mario Geiger, Stefano Spigler, Arthur Jacot, and Matthieu Wyart. Disentangling feature and lazy training in deep neural networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2020(11):113301, 2020. arXiv:1906.08034.

[31] Antoine Georges, Gabriel Kotliar, Werner Krauth, and Marcelo J. Rozenberg. Dynamical mean-field theory of strongly correlated fermion systems and the limit of infinite dimensions. *Reviews of Modern Physics*, 68(1):13–125, January 1996.

[32] Cédric Gerbelot, Emanuele Troiani, Francesca Mignacco, Florent Krzakala, and Lenka Zdeborová. Rigorous dynamical mean-field theory for stochastic gradient descent methods. *SIAM Journal on Mathematics of Data Science*, 6(2), 2024. arXiv:2210.06591.

[33] Nigel Goldenfeld. *Lectures On Phase Transitions And The Renormalization Group*. CRC Press, Boca Raton, March 2018.

[34] Andrey Gromov. Grokking modular arithmetic, 2023. arXiv:2301.02679.

[35] Géza Györgyi. First-order transition to perfect generalization in a neural network with binary synapses. *Physical Review A*, 41(12):7097–7100, 1990.

[36] Boris Hanin. Random neural networks in the infinite width limit as gaussian processes. *The Annals of Applied Probability*, 33(6A):4798–4819, 2023.

[37] Boris Hanin. Special lectures on the mathematics of deep learning. Five-lecture series, Department of Mathematics, University of Chicago, 6–9 April 2026. Video recordings, YouTube, 2026. `https://www.youtube.com/@uchicagomath`.

[38] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. In *International Conference on Computer Vision (ICCV)*, 2015. arXiv:1502.01852.

[39] Tom Henighan, Jared Kaplan, Mor Katz, Mark Chen, Christopher Hesse, Jacob Jackson, Heewoo Jun, Tom B. Brown, Prafulla Dhariwal, Scott Gray, et al. Scaling laws for autoregressive generative modeling, 2020. arXiv:2010.14701.

[40] Danny Hernandez, Jared Kaplan, Tom Henighan, and Sam McCandlish. Scaling laws for transfer, 2021. arXiv:2102.01293.

[41] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, et al. Training compute-optimal large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2203.15556.

[42] Arthur Jacot, Franck Gabriel, and Clément Hongler. Neural tangent kernel: convergence and generalization in neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1806.07572.

[43] Nikhil Kandpal, Haikang Deng, Adam Roberts, Eric Wallace, and Colin Raffel. Large language models struggle to learn long-tail knowledge. In *International Conference on Machine Learning (ICML)*, 2023. arXiv:2211.08411.

[44] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.

[45] Devvrit Khatri, Lovish Madaan, Rishabh Tiwari, Rachit Bansal, Sai Surya Duvvuri, Manzil Zaheer, Inderjit S. Dhillon, David Brandfonbrener, and Rishabh Agarwal. The art of scaling reinforcement learning compute for LLMs, 2025. arXiv:2510.13786.

[46] G. Kotliar, S. Y. Savrasov, K. Haule, V. S. Oudovenko, O. Parcollet, and C. A. Marianetti. Electronic structure calculations with dynamical mean-field theory. *Rev. Mod. Phys.*, 78:865–951, Aug 2006.

[47] R. Kubo. The fluctuation-dissipation theorem. *Reports on Progress in Physics*, 29(1):255, January 1966.

[48] Ryogo Kubo. Statistical-Mechanical Theory of Irreversible Processes. I. General Theory and Simple Applications to Magnetic and Conduction Problems. *Journal of the Physical Society of Japan*, 12(6):570–586, June 1957.

[49] Tanishq Kumar, Blake Bordelon, Samuel J. Gershman, and Cengiz Pehlevan. Grokking as the transition from lazy to rich training dynamics, 2024. arXiv:2310.06110.

[50] T. Lancaster and S. Blundell. *Quantum Field Theory for the Gifted Amateur*. OUP Oxford, 2014.

[51] Yann LeCun, Léon Bottou, Genevieve B. Orr, and Klaus-Robert Müller. Efficient backprop. In *Neural Networks: Tricks of the Trade*, volume 1524 of *Lecture Notes in Computer Science*. Springer, 1998.

[52] Jaehoon Lee, Yasaman Bahri, Roman Novak, Samuel S. Schoenholz, Jeffrey Pennington, and Jascha Sohl-Dickstein. Deep neural networks as Gaussian processes. In *International Conference on Learning Representations (ICLR)*, 2018. arXiv:1711.00165.

[53] Chan Li and Nigel Goldenfeld. Broken Ergodicity and the Violation of the Fluctuation-Dissipation Theorem Lead to Generalization Beyond Overfitting in Machine Learning, July 2026.

[54] J. Lin. Feature identification via the empirical NTK, 2025. arXiv:2510.00468.

[55] Alexander Maloney, Daniel A. Roberts, and James Sully. A solvable model of neural scaling laws. *arXiv preprint arXiv:2210.16859*, 2022.

[56] Song Mei, Andrea Montanari, and Phan-Minh Nguyen. A mean field view of the landscape of two-layer neural networks. *Proceedings of the National Academy of Sciences*, 115(33):E7665–E7671, 2018.

[57] Eric J. Michaud, Ziming Liu, Uzay Girit, and Max Tegmark. The quantization model of neural scaling. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2303.13506.

[58] Francesca Mignacco, Florent Krzakala, Pierfrancesco Urbani, and Lenka Zdeborová. Dynamical mean-field theory for stochastic gradient descent in Gaussian mixture classification*. *Journal of Statistical Mechanics: Theory and Experiment*, 2021(12):124008, December 2021.

[59] Francesca Mignacco and Pierfrancesco Urbani. The effective noise of Stochastic Gradient Descent. *Journal of Statistical Mechanics: Theory and Experiment*, 2022(8):083405, August 2022.

[60] Andrea Montanari and Pierfrancesco Urbani. Dynamical Decoupling of Generalization and Overfitting in Large Two-Layer Networks, October 2025.

[61] Niklas Muennighoff, Alexander M. Rush, Boaz Barak, Teven Le Scao, Aleksandra Piktus, Nouamane Tazi, Sampo Pyysalo, Thomas Wolf, and Colin Raffel. Scaling data-constrained language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2305.16264.

[62] Radford M. Neal. *Bayesian Learning for Neural Networks*, volume 118 of *Lecture Notes in Statistics*. Springer, 1996.

[63] Lars Onsager and Stefan Machlup. Fluctuations and irreversible processes. *Physical Review*, 91(6):1505–1512, 1953.

[64] R. K. Pathria and Paul D. Beale. *Statistical Mechanics*. Elsevier/Academic Press, Amsterdam ; Boston, 3rd ed edition, 2011.

[65] Ben Poole, Subhaneil Lahiri, Maithra Raghu, Jascha Sohl-Dickstein, and Surya Ganguli. Exponential expressivity in deep neural networks through transient chaos. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2016. arXiv:1606.05340.

[66] Tomer Porian, Mitchell Wortsman, Jenia Jitsev, Ludwig Schmidt, and Yair Carmon. Resolving discrepancies in compute-optimal scaling of language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2406.19146.

[67] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: generalization beyond overfitting on small algorithmic datasets, 2022. arXiv:2201.02177.

[68] Charles Renshaw-Whitman. Iliad physics learning: lectures and exercise notebooks for the august 2026 iliad intensive. `https://github.com/CharlesR-W/IliadPhysicsLearning`, 2026.

[69] Zohar Ringel, Noa Rubin, Edo Mor, Moritz Helias, and Inbar Seroussi. *Applications of Statistical Field Theory in Deep Learning*. Foundations and Trends in Machine Learning. Now Publishers, 2025. arXiv:2502.18553.

[70] Hannes Risken. *The Fokker–Planck Equation: Methods of Solution and Applications*. Springer, 2 edition, 1996.

[71] Daniel A. Roberts, Sho Yaida, and Boris Hanin. *The Principles of Deep Learning Theory: An Effective Theory Approach to Understanding Neural Networks*. Cambridge University Press, 2022. arXiv:2106.10165.

[72] Grant M. Rotskoff and Eric Vanden-Eijnden. Trainability and accuracy of artificial neural networks: an interacting particle system approach. *Communications on Pure and Applied Mathematics*, 75(9):1889–1935, 2022. arXiv:1805.00915.

[73] Noa Rubin, Inbar Seroussi, and Zohar Ringel. Grokking as a first order phase transition in two layer networks. In *The Twelfth International Conference on Learning Representations (ICLR)*, 2024.

[74] Rylan Schaeffer, Brando Miranda, and Sanmi Koyejo. Are emergent abilities of large language models a mirage? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2304.15004.

[75] Samuel S. Schoenholz, Justin Gilmer, Surya Ganguli, and Jascha Sohl-Dickstein. Deep information propagation. In *International Conference on Learning Representations (ICLR)*, 2017. arXiv:1611.01232.

[76] Inbar Seroussi, Gadi Naveh, and Zohar Ringel. Separation of scales and a thermodynamic description of feature learning in some cnns. *Nature Communications*, 14:908, 2023.

[77] H. Sebastian Seung, Haim Sompolinsky, and Naftali Tishby. Statistical mechanics of learning from examples. *Physical Review A*, 45(8):6056–6091, 1992.

[78] Utkarsh Sharma and Jared Kaplan. A neural scaling law from the dimension of the data manifold, 2020. arXiv:2004.10802.

[79] James B. Simon, Madeline Dickens, Dhruva Karkada, and Michael R. DeWeese. The eigenlearning framework: a conservation law perspective on kernel ridge regression and wide neural networks. *Transactions on Machine Learning Research (TMLR)*, 2023. arXiv:2110.03922.

[80] Jamie Simon, Daniel Kunin, Alexander Atanasov, Jeremy Cohen, Arthur Jacot, Eric J. Michaud, Enric Boix-Adserà, Nikhil Ghosh, Mason Kamb, Berkan Ottlik, Blake Bordelon, Florentin Guth, Dhruva Karkada, and Joseph Turnbull. There will be a scientific theory of deep learning. *arXiv preprint arXiv:2604.21691*, 2026.

[81] Justin Sirignano and Konstantinos Spiliopoulos. Mean field analysis of neural networks: a law of large numbers. *SIAM Journal on Applied Mathematics*, 80(2):725–752, 2020.

[82] Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling LLM test-time compute optimally can be more effective than scaling model parameters, 2024. arXiv:2408.03314.

[83] H. Sompolinsky, A. Crisanti, and H. J. Sommers. Chaos in Random Neural Networks. *Physical Review Letters*, 61(3):259–262, July 1988.

[84] Konstantinos Spiliopoulos, Richard B. Sowers, and Justin Sirignano. *Mathematical Foundations of Deep Learning Models and Algorithms*, volume 252 of *Graduate Studies in Mathematics*. American Mathematical Society, 2025.

[85] Jonas Stapmanns, Tobias Kühn, David Dahmen, Thomas Luu, Carsten Honerkamp, and Moritz Helias. Self-consistent formulations for stochastic nonlinear neuronal dynamics. *Physical Review E*, 101(4):042124, April 2020.

[86] Alain-Sol Sznitman. Topics in propagation of chaos. In *École d'Été de Probabilités de Saint-Flour XIX — 1989*, volume 1464 of *Lecture Notes in Mathematics*, pages 165–251. Springer, 1991.

[87] David Tong. Lectures on quantum field theory. University of Cambridge, 2006. Lecture notes accessed for Part III of the Mathematical Tripos.

[88] David Tong. Lectures on kinetic theory. Lecture notes, 2012.

[89] David Tong. Statistical field theory. Lecture notes available at `https://davidtong.org/teaching/statistical-field-theory/`, 2012. Lectures presented for Part III of the Mathematical Tripos.

[90] David Tong. Statistical physics. Lecture notes available online at `https://davidtong.org/teaching/statistical-physics/`, 2012. Aimed at final year undergraduates.

[91] Nicolaas G. van Kampen. *Stochastic Processes in Physics and Chemistry*. North-Holland, 3 edition, 2007.

[92] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. Emergent abilities of large language models. *Transactions on Machine Learning Research*, 2022. arXiv:2206.07682.

[93] Christopher K. I. Williams. Computing with infinite networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 1997.

[94] Lechao Xiao, Yasaman Bahri, Jascha Sohl-Dickstein, Samuel S. Schoenholz, and Jeffrey Pennington. Dynamical isometry and a mean field theory of CNNs: how to train 10,000-layer vanilla convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2018. arXiv:1806.05393.

[95] Greg Yang. Tensor programs I: Wide feedforward or recurrent neural networks of any architecture are gaussian processes. In *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*, 2019.

[96] Greg Yang and Edward J. Hu. Tensor programs IV: feature learning in infinite-width neural networks. In *International Conference on Machine Learning (ICML)*, 2021. arXiv:2011.14522.

[97] Greg Yang, Edward J. Hu, Igor Babuschkin, Szymon Sidor, Xiaodong Liu, David Farhi, Nick Ryder, Jakub Pachocki, Weizhu Chen, and Jianfeng Gao. Tensor programs V: tuning large neural networks via zero-shot hyperparameter transfer. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2203.03466.

[98] Lenka Zdeborová and Florent Krzakala. Statistical physics of inference: thresholds and algorithms. *Advances in Physics*, 65(5):453–552, 2016.

[99] J. Zinn-Justin. *Quantum Field Theory and Critical Phenomena*. International Series of Monographs on Physics. Clarendon Press, 2002.