

信息、物理与计算

Information, Physics, and Computation

Marc Mézard 和 Andrea Montanari

冻结作者草稿可见内容中文候选

作者章节草稿 · Oxford University Press 原书 2009
Model: gpt-6.1-sol（本轮；早期模型未核实）
审核：曹溪能
Updated: 2026-11-06

译本说明

本译本以本地冻结的作者章节草稿 Part A–F 为范围，现已包含全部可见的第 1–16、18–22 章、附录 A 和 344 条参考文献。它不等同于 2009 年 Oxford University Press 正式整书：正式第 17 章正文未取得；Part D 最后一页（印 374）的第 16 章 Notes 在 “provides a nice” 处截断，后续不可见。正式前言、索引等未见于这些文件，亦不补造。正文所指第 17 章内容因此无法在本译本核对。

六份草稿日期不完全相同，正文引文与书目、跨章号和公式存在源差异。源公式和论断默认保留，明确的疑点以译注区别。图中箭头节点关系用可编辑 tikzcd 或原生绘图重建，其他源图保留忠实裁片；原图资产及来源记录随源码保留。书后引文差异说明保留不能唯一匹配的历史引用，不凭同作者和相似题名猜定版本。

本轮作者阶段完成语言与术语、数学结构及构建版面三类自查。此前的独立限定审校及修订证据按实际范围继承；完整候选仍待独立内容审校、独立源码 ZIP 解包重建和主控最终验收，不以作者自查或可编译代替这些门禁。这里的固定字段 “审核：曹溪能” 遵循本项目封面规范，不证明曹溪能本人逐页审阅。

本轮实际模型为 gpt-6.1-sol，推理等级 high；早期初译的具体模型未核实，不反推。材料限本地工作与审校，未发布网站。

审核：曹溪能

目录

译本说明 **1**

第一章 信息论导论 **13**

1.1 随机变量 13
1.2 熵 14
1.3 随机变量序列与熵率 17
1.4 相关变量与互熵 18
1.5 数据压缩 19
1.5.1 码字 19
1.5.2 最优压缩与熵 21
1.6 数据传输 22
1.6.1 通信信道 23
1.6.2 纠错码 24
1.6.3 信道编码定理 26

第二章 统计物理与概率论 **29**

2.1 Boltzmann 分布 29
2.2 热力学势 32
2.3 涨落耗散关系 35
2.4 热力学极限 36
2.5 铁磁体与 Ising 模型 38
2.5.1 一维情形 40
2.5.2 Curie–Weiss 模型 42
2.6 Ising 自旋玻璃 45

第三章 组合优化导论 **49**

3.1 第一个例子：最小生成树 49
3.1.1 问题定义与图论基础 50
3.1.2 最小生成树的一个高效算法 50
3.2 一般定义 52
3.3 更多例子 52
3.3.1 欧拉回路 52

3.3.2 Hamilton 圈 . . . 53
3.3.3 旅行商问题 . . . 53
3.3.4 分配问题 . . . 53
3.3.5 可满足性 . . . 53
3.3.6 着色与顶点覆盖 . . . 54
3.3.7 数字划分 . . . 54
3.4 计算复杂性理论初步 . . . 54
3.4.1 最坏情况 . . . 54
3.4.2 是否为多项式? . . . 54
3.4.3 优化、求值与判定 . . . 55
3.4.4 多项式归约 . . . 55
3.4.5 复杂性类 . . . 56
3.4.6 P = NP? . . . 57
3.4.7 其他复杂性类 . . . 58
3.5 优化与统计物理 . . . 58
3.5.1 一般关系 . . . 58
3.5.2 自旋玻璃与最大割 . . . 59
3.6 优化与编码 . . . 60

第四章 概率工具箱 63
4.1 多个随机变量：定性预览 . . . 63
4.2 独立变量的大偏差 . . . 64
4.2.1 一组观测有多典型? . . . 64
4.2.2 经验平均有多典型? . . . 66
4.2.3 渐近均分性 . . . 67
4.3 相关变量 . . . 69
4.3.1 Legendre 变换 . . . 69
4.3.2 例子 . . . 70
4.3.3 Gärtner–Ellis 定理 . . . 72
4.3.4 典型序列 . . . 73
4.4 Gibbs 自由能 . . . 74
4.5 Monte Carlo 方法 . . . 76
4.6 模拟退火 . . . 80
4.7 附录：物理学家处理 Sanov 定理的方法 . . . 82

第五章 随机能量模型 85
5.1 模型定义 . . . 85
5.2 REM 的热力学 . . . 86
5.2.1 直接计算熵 . . . 86
5.2.2 热力学与相变 . . . 88

5.3 凝聚现象 . . . 91
5.4 关于淬火平均和退火平均的说明 . . . 92
5.5 注释 . . . 94

第六章 随机码系综 95
6.1 码系综 . . . 95
6.2 随机码系综的几何 . . . 97
6.3 在二元对称信道上通信 . . . 99
6.3.1 码字 MAP 解码 . . . 99
6.3.2 符号 MAP 解码 . . . 100
6.3.3 有限温度解码 . . . 103
6.4 用随机码实现无错误通信 . . . 105
6.5 再谈几何：球堆积 . . . 107
6.6 其他随机码 . . . 110
6.7 关于编码理论与无序系统的说明 . . . 111

第七章 数字划分 115
7.1 公平地分成两组? . . . 115
7.2 算法问题 . . . 116
7.2.1 一个 NP 完全问题 . . . 116
7.2.2 简单启发式与完备算法 . . . 116
7.3 随机列表划分：实验 . . . 117
7.4 随机代价模型 . . . 119
7.4.1 模型定义 . . . 119
7.4.2 相变 . . . 120
7.4.3 两个相的研究 . . . 121
7.5 随机列表划分：严格结果 . . . 122
7.5.1 积分表示 . . . 123
7.5.2 矩估计 . . . 123

第八章 复本理论导论 127
8.1 随机能量模型的复本解 . . . 127
8.1.1 复本对称鞍点 . . . 129
8.1.2 一步复本对称性破缺鞍点 . . . 131
8.1.3 关于复本解的讨论 . . . 132
8.1.4 凝聚 . . . 133
8.2 全连接 p 自旋玻璃模型 . . . 134
8.2.1 复本计算 . . . 135
8.2.2 重叠分布 . . . 140
8.3 极值统计与 REM . . . 141

8.4 附录：RS 鞍点的稳定性 143

第九章 因子图与图系综 147

9.1 因子图 147
9.1.1 定义与一般性质 147
9.1.2 例子 150
9.2 因子图系综：定义 153
9.3 随机因子图：基本性质 154
9.3.1 度分布 154
9.3.2 小子图 156
9.4 随机因子图：巨型分支 158
9.4.1 有限树中的节点 158
9.4.2 巨型分支的大小 159
9.4.3 树的计数 160
9.5 随机图的局部树状结构 161
9.5.1 节点邻域 161
9.5.2 环 162

第十章 可满足性 165

10.1 可满足性问题 165
10.1.1 SAT 与 UNSAT 公式 165
10.2 算法 167
10.2.1 简单情形：2-SAT 167
10.2.2 一般完备算法 168
10.2.3 不完备搜索 170
10.3 随机 K 可满足性系综 172
10.3.1 数值实验 172
10.4 随机 2-SAT 174
10.5 随机 $K \geq 3$ SAT 的相变 174
10.5.1 可满足性阈值猜想 174
10.5.2 上界 175
10.5.3 下界 177

第十一章 低密度奇偶校验码 183

11.1 定义 183
11.1.1 布尔线性代数 183
11.1.2 因子图 184
11.1.3 给定度分布的系综 184
11.2 码本的几何 185
11.2.1 权重枚举函数：固定度 186

11.2.2 权重枚举函数：一般情形 . . . 186
11.2.3 短距离性质 . . . 189
11.2.4 码率 . . . 191
11.3 LDPC 码在二元对称信道上的容量 . . . 192
11.3.1 下界 . . . 192
11.3.2 上界 . . . 195
11.3.3 界的总结 . . . 196
11.4 一种简单解码器：比特翻转 . . . 196

第十二章 自旋玻璃 201
12.1 自旋玻璃与因子图 . . . 201
12.1.1 广义 Ising 模型 . . . 201
12.1.2 自旋玻璃系综 . . . 202
12.2 自旋玻璃：约束与阻挫 . . . 203
12.2.1 规范变换 . . . 204
12.2.2 Nishimori 温度… . . . 205
12.2.3 …及其与概率的关系 . . . 206
12.3 什么是玻璃相? . . . 207
12.3.1 自发局域磁化强度 . . . 207
12.3.2 自旋玻璃磁化率 . . . 208
12.3.3 重叠分布函数 $P(q)$ . . . 209
12.3.4 从重叠分布到 ϵ 耦合方法 . . . 211
12.3.5 1RSB 系统的聚簇相与势 . . . 212
12.3.6 克隆与复杂度函数 . . . 214
12.4 例：SK 模型的相图 . . . 216

第十三章 桥接 219
13.1 统计推断 . . . 219
13.1.1 Bayesian 网络 . . . 219
13.1.2 编码、统计物理与组合优化中的推断 . . . 222
13.2 Monte Carlo 方法：通过采样进行推断 . . . 223
13.2.1 LDPC 码 . . . 223
13.2.2 Ising 模型 . . . 225
13.2.3 MAX-SAT . . . 229
13.3 自由能垒 . . . 229

第十四章 信念传播 235
14.1 两个例子 . . . 235
14.1.1 例一：Ising 链 . . . 235
14.1.2 例二：树奇偶校验码 . . . 237

14.2 树图上的信念传播 . . . 239
14.2.1 三个问题 . . . 239
14.2.2 BP 方程 . . . 239
14.2.3 关联与能量 . . . 241
14.2.4 熵 . . . 242
14.2.5 成对模型 . . . 244
14.3 优化：最大积与最小和 . . . 245
14.3.1 最大边缘 . . . 245
14.3.2 消息传递 . . . 245
14.3.3 警告传播 . . . 247
14.4 有环 BP . . . 248
14.4.1 Bethe 自由熵与变分方法 . . . 249
14.4.2 关联 . . . 251
14.5 一般消息传递算法 . . . 253
14.6 概率分析 . . . 254
14.6.1 假设 . . . 254
14.6.2 密度演化方程 . . . 255
14.6.3 复本对称腔方法 . . . 257
14.6.4 数值方法 . . . 258

第十五章 用信念传播解码 261
15.1 BP 解码算法 . . . 261
15.2 分析：密度演化 . . . 262
15.2.1 密度演化方程 . . . 263
15.2.2 基本性质一：对称性 . . . 263
15.2.3 基本性质二：物理退化 . . . 265
15.2.4 数值实现与阈值 . . . 267
15.2.5 局部稳定性 . . . 268
15.3 擦除信道的 BP 解码 . . . 269
15.3.1 BP、剥离与停止集 . . . 270
15.3.2 密度演化 . . . 271
15.3.3 系综优化 . . . 272
15.4 Bethe 自由能与最优解码 . . . 274

第十六章 分配问题 277
16.1 分配及随机分配系综 . . . 277
16.2 消息传递及其概率分析 . . . 278
16.2.1 统计物理表述与计数 . . . 278
16.2.2 信念传播方程 . . . 279
16.2.3 零温：最小和算法 . . . 280

16.2.4 分布不动点与 $\zeta(2)$ . . . 281
16.2.5 非零温度与稳定性分析 . . . 282
16.3 多项式消息传递算法 . . . 285
16.3.1 计算树 . . . 286
16.3.2 最小和收敛的证明 . . . 286
16.3.3 几点说明 . . . 288
16.4 组合结果 . . . 288
16.4.1 Coppersmith–Sorkin 公式与 Parisi 公式 . . . 288
16.4.2 从 k-分配到 $k+1$-分配 . . . 289
16.4.3 C–S 公式的证明 . . . 290
16.5 练习：多指标分配 . . . 291

第十八章 布尔变量线性方程 293
18.1 定义与一般说明 . . . 293
18.1.1 线性系统 . . . 293
18.1.2 随机 XORSAT . . . 296
18.2 信念传播 . . . 297
18.2.1 BP 消息与密度演化 . . . 297
18.2.2 关联衰减 . . . 298
18.3 核渗流与 BP . . . 300
18.3.1 2-核与剥离 . . . 300
18.3.2 团簇 . . . 300
18.3.3 核、骨架与 BP . . . 301
18.4 随机 XORSAT 的 SAT–UNSAT 阈值 . . . 301
18.4.1 核的大小 . . . 302
18.4.2 阈值 . . . 303
18.5 Hard-SAT 相：解的团簇 . . . 307
18.6 另一种途径：腔方法 . . . 308

第十九章 一步复本对称性破缺腔方法 313
19.1 超越 BP：多态 . . . 313
19.1.1 Bethe 测度 . . . 313
19.1.2 几种一般图景 . . . 315
19.2 1RSB 腔方程 . . . 316
19.2.1 计数 BP 不动点 . . . 316
19.2.2 辅助模型上的消息传递 . . . 318
19.2.3 计算复杂度 . . . 320
19.2.4 小结 . . . 320
19.2.5 随机图模型与密度演化 . . . 321
19.2.6 数值实现 . . . 322

19.3 第一个应用：XORSAT 323
19.3.1 BP 方程 323
19.3.2 1RSB 腔方程 324
19.3.3 复杂度 325
19.4 特殊取值 $x = 1$ 326
19.4.1 回到 BP 326
19.4.2 更简单的递推 327
19.5 调查传播 328
19.5.1 SP(y) 方程 328
19.5.2 能量复杂度 330
19.5.3 约束满足与二值变量 330
19.5.4 再看 XORSAT 331
19.6 1RSB 相的性质 332
19.6.1 动力学 1RSB 333
19.6.2 静态 1RSB 334
19.6.3 1RSB 何时失效? 334

第二十章 随机 K-可满足性 339
20.1 信念传播与复本对称分析 339
20.1.1 BP 方程 339
20.1.2 统计分析 340
20.1.3 BP 引导消元 342
20.1.4 RS 分析的适用性 343
20.2 调查传播与 1RSB 相 343
20.2.1 SP(y) 方程 343
20.2.2 自由熵 $F^{\mathrm{RSB},e}$ 344
20.2.3 大 y 极限：SP 方程 345
20.2.4 SAT–UNSAT 阈值 345
20.2.5 SP 引导消元 347
20.3 完整相图的几点认识 350
20.3.1 团簇熵 350
20.3.2 $K \geq 4$ 的凝聚转变 351
20.4 练习：随机图着色 352

第二十一章 编码理论中的玻璃态 355
21.1 局域搜索与亚稳态 355
21.1.1 受约束优化解码 355
21.1.2 Δ 局域搜索解码 356
21.1.3 模拟退火解码 357
21.2 二元擦除信道 359

21.2.1 能量 1RSB 方程 . . . 359
21.2.2 BP 阈值与亚稳性的出现 . . . 360
21.3 一般二元无记忆对称信道 . . . 362
21.3.1 1RSB 腔途径 . . . 362
21.3.2 动力学相变 . . . 364
21.3.3 亚稳态与 BP 阈值 . . . 364
21.4 亚稳态与近码字 . . . 366

第二十二章 仍在继续的故事 369
22.1 Gibbs 测度与长程关联 . . . 369
22.1.1 关于纯态的定义 . . . 370
22.1.2 关联衰减的概念 . . . 371
22.1.3 通用情景 . . . 372
22.2 更高阶的复本对称性破缺 . . . 374
22.2.1 总体图景 . . . 374
22.2.2 2RSB 的形式 . . . 376
22.2.3 1RSB 相的局部稳定性 . . . 377
22.2.4 腔方法内部的开放问题 . . . 379
22.3 相结构与算法行为 . . . 380
注释 . . . 382

附录 A 符号与记号 385
A.1 等价关系 . . . 385
A.2 增长阶 . . . 386
A.3 组合与概率 . . . 386
A.4 数学记号汇总 . . . 387
A.5 信息论 . . . 388
A.6 因子图 . . . 388
A.7 腔方法与消息传递 . . . 389

引文与书目差异说明 391

参考文献 393

第一章　信息论导论

本章介绍信息论的一些基本概念，以及全书使用的概率定义与记号。我们将在这里引入熵的概念，它是全书主题的基础。我们还将介绍信息论的主要问题——数据压缩与纠错——并陈述 Shannon 定理。

1.1　随机变量

本书主要研究大量离散随机变量的行为。离散随机变量 X 由它能够取的值的集合 $\mathcal{X}$（我们假设该集合有限）及其概率分布 $\{p_X(x)\}_{x\in\mathcal{X}}$ 完全确定。[1]其中 $p_X(x)$ 是随机变量 X 取值为 x 的概率。概率分布 $p_X : \mathcal{X} \to [0,1]$ 必须满足归一化条件

$$\sum_{x\in\mathcal{X}} p_X(x) = 1. \tag{1.1}$$

我们用 $\mathbb{P}(A)$ 表示事件 $A \subseteq \mathcal{X}$ 的概率，因此 $p_X(x) = \mathbb{P}(X = x)$。为了简化记号，在不产生歧义时，用 $p(x)$ 表示 $p_X(x)$。

如果 $f(X)$ 是随机变量 X 的实值函数，$f(X)$ 的期望值（我们也称之为 f 的平均值）记为

$$\mathbb{E}f = \sum_{x\in\mathcal{X}} p_X(x) f(x). \tag{1.2}$$

尽管我们主要关注取值于有限空间的随机变量，有时也会使用取值于 $\mathbb{R}^d$ 或某个光滑有限维流形的连续随机变量。我们用 $dp_X(x)$ 表示“无穷小元素” dx 的概率测度。每当 p_X 存在关于 Lebesgue 测度的密度时，我们用 $p_X(x)$ 表示该密度在点 x 处的值。变量 X 取值于某个（Borel）集合 $A \subseteq \mathcal{X}$ 的总概率 $\mathbb{P}(X \in A)$ 由积分给出：

$$\mathbb{P}(X \in A) = \int_{x\in A} dp_X(x) = \int I(x \in A)\, dp_X(x), \tag{1.3}$$

其中第二种形式使用逻辑命题 s 的示性函数 $I(s)$：当命题 s 为真时它等于 1，为假时等于 0。

实值函数 $f(x)$ 的期望值由 $\mathcal{X}$ 上的积分给出：

$$\mathbb{E}f(X) = \int f(x)\, dp_X(x). \tag{1.4}$$

有时我们写作 $\mathbb{E}_X f(X)$，以明确需要积分的变量。我们常用缩写 pdf 表示概率密度函数 $p_X(x)$。

[1]用概率论的术语说（下文将避免这种说法），我们取概率空间 $(\mathcal{X}, \mathcal{P}(\mathcal{X}), p_X)$，其中 $\mathcal{P}(\mathcal{X})$ 是 $\mathcal{X}$ 的子集构成的 σ-代数，$p_X = \sum_{x\in\mathcal{X}} p_X(x)\,\delta_x$。

例 1.1. 一个有 M 个面的公平骰子满足 $\mathcal{X} = \{1, 2, \ldots, M\}$，且对所有 $i \in \{1, \ldots, M\}$ 有 $p(i) = 1/M$。x 的平均值为 $\mathbb{E}X = (1 + \cdots + M)/M = (M + 1)/2$。

例 1.2 (高斯变量)**.** 连续变量 $X \in \mathbb{R}$ 若具有如下概率密度，则它服从均值为 m、方差为 σ^2 的高斯分布：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{[x-m]^2}{2\sigma^2}\right). \tag{1.5}$$

此时 $\mathbb{E}X = m$，$\mathbb{E}(X-m)^2 = \sigma^2$。

本章记号主要针对离散变量。将求和 $\sum_x$ 替换为积分并将 $p(x)$ 理解为概率密度后，大多数表达式可推广至连续变量。

习题 1.1 (Jensen 不等式)**.** 设 X 是取值于集合 $\mathcal{X} \subseteq \mathbb{R}$ 的随机变量，f 是凸函数（即对所有 x, y 和所有 $\alpha \in [0,1]$，有 $f(\alpha x + (1-\alpha)y) \le \alpha f(x) + (1-\alpha) f(y)$）。则

$$\mathbb{E}f(X) \ge f(\mathbb{E}X). \tag{1.6}$$

为简单起见，假设 $\mathcal{X}$ 为有限集合且 $|\mathcal{X}| = n$，用对 n 的递归证明这一等式。

1.2 熵

概率分布为 $p(x)$ 的离散随机变量 X 的熵 H_X 定义为

$$H_X \equiv -\sum_{x \in \mathcal{X}} p(x) \log_2 p(x) = \mathbb{E}\left[\log_2 \frac{1}{p(X)}\right]. \tag{1.7}$$

我们按连续性定义 $0 \log_2 0 = 0$。需要强调熵对 X 的概率分布的依赖时，也写作 $H(p)$。

本章使用以 2 为底的对数，它很适合数字通信，此时熵以比特为单位。在其他场合，人们也使用自然对数（以 $e \approx 2.7182818$ 为底），这时有时称熵以奈特（nat）为单位。实际上，两种定义只相差一个整体乘法常数，相当于改变计量单位。在不产生歧义时，我们用 H 代替 H_X。

直观地说，熵衡量随机变量的不确定性。它有时称为缺失信息：熵越大，人们对随机变量取值的先验信息就越少。粗略地说，这一度量是变量可能取到的典型值的数目的对数，以下例子对此有所说明。

例 1.3. 一枚公平硬币的两个取值等概率，其熵为 *1* 比特。

例 1.4. 设想抛掷 M 枚公平硬币，所有可能结果的数目为 2^M，熵为 M 比特。

例 1.5. 一个有 M 个面的公平骰子的熵为 $\log_2 M$。

例 1.6 (Bernoulli 过程)**.** 随机变量 X 以概率 $p(0) = q$、$p(1) = 1 - q$ 取值 $0, 1$。它的熵为

$$H_X = -q \log_2 q - (1-q) \log_2 (1-q). \tag{1.8}$$

图 *1.1* 给出了该熵随 q 的变化。当 $q = 0$ 或 $q = 1$ 时结果确定，熵为零；当 $q = 1/2$ 时不确定性最大，熵达到最大值。

由于 *Bernoulli* 变量无处不在，方便起见，我们引入其熵函数 $H(q) \equiv -q \log q - (1-q) \log(1-q)$。

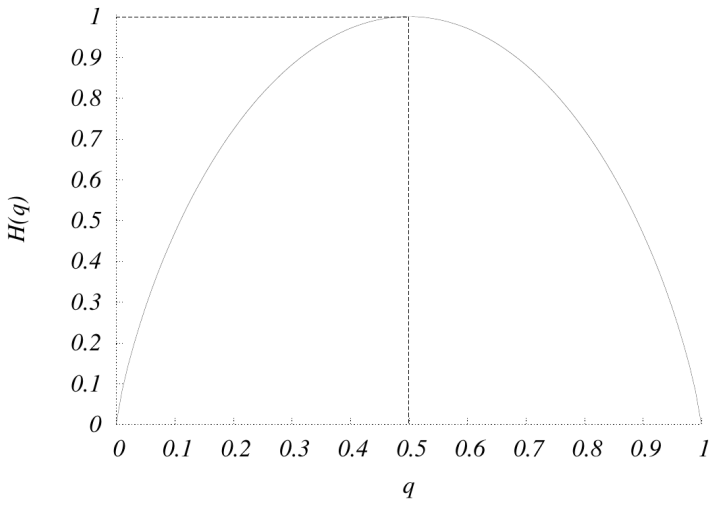


图 1.1: 二值变量 $p(X=0)=q$、$p(X=1)=1-q$ 的熵 $H(q)$ 随 q 的变化。图取自 Part A 草稿第 4 页。

习题 1.2. 一个不公平的四面骰子满足 $p(1)=1/2$、$p(2)=1/4$、$p(3)=p(4)=1/8$，其熵为 $H=7/4$，小于相应公平骰子的熵。

习题 1.3. *DNA* 由四种碱基 A、T、G、C 组成的序列构成。在灵长类动物的天然 *DNA* 中，四种碱基的频率近似相同；如果作出各碱基相互独立的简化假设，则每个碱基的熵为 $H=-\log_2(1/4)=2$。在某些细菌属中，浓度可能有较大差异：$p(G)=p(C)=0.38$、$p(A)=p(T)=0.12$，因而熵较小，约为 $H\approx 1.79$。

习题 1.4. 从某种直观意义上说，随机变量的熵与其所关联的“风险”或“惊奇”有关。本例讨论一种使这些概念更加精确的简单方法。

考虑一位赌徒，他对一列 *Bernoulli* 随机变量 $X_t\in\{0,1\}$、$t\in\{0,1,2,\ldots\}$ 下注，其均值为 $\mathbb{E}X_t=p$。设想他知道 X_t 的分布，在时刻 t，他将财富的比例 $w(1)=p$ 押在 *1* 上，将比例 $w(0)=1-p$ 押在 *0* 上。他输掉押错数字的所有钱，而押对数字的钱则翻倍。将时刻 t 财富的平均翻倍率定义为

$$W_t=\frac{1}{t}\,\mathbb{E}\log_2\left\{\prod_{t'=1}^{t}2w(X_{t'})\right\}. \tag{1.9}$$

容易证明，期望翻倍率 $\mathbb{E}W_t$ 与 X_t 的熵有关：$\mathbb{E}W_t=1-H(p)$。换言之，通过可预测事件赚钱更容易。[2]

另一种与熵直接相关的概念是 Kullback–Leibler（KL）散度。对同一有限空间 $\mathcal{X}$ 上的概率分布 $p(x)$ 和 $q(x)$，它定义为

$$D(q\|p)\equiv\sum_{x\in\mathcal{X}}q(x)\log\frac{q(x)}{p(x)}. \tag{1.10}$$

[2]译注：式 (1.9) 已对随机变量取期望，因而按所写定义 W_t 是确定量；原文后面再写 $\mathbb{E}W_t$，此处照录。

我们约定 $0\log 0 = 0$、$0\log(0/0) = 0$。容易证明：(i) $D(q\|p)$ 关于 $q(x)$ 是凸的；(ii) $D(q\|p) \geq 0$；(iii) 除非 $q(x) \equiv p(x)$，否则 $D(q\|p) > 0$。后两条性质来自对数函数的凹性（即函数 $-\log x$ 的凸性）和 Jensen 不等式 (1.6)：若 $\mathbb{E}$ 表示关于分布 $q(x)$ 的期望，则 $-D(q\|p) = \mathbb{E}\log[p(x)/q(x)] \leq \log \mathbb{E}[p(x)/q(x)] = 0$。KL 散度 $D(q\|p)$ 因此看起来像概率分布 q 与 p 之间的距离，尽管它不对称。[3]

熵作为信息度量的重要性及其用途来自下列性质：

1. $H_X \geq 0$。

2. $H_X = 0$ 当且仅当随机变量 X 是确定的，即 X 以概率 1 取某一个值。

3. 在包含 M 个元素的集合 $\mathcal{X}$ 上的所有概率分布中，当所有事件 x 等概率、即 $p(x) = 1/M$ 时，H 达到最大值，此时 $H_X = \log_2 M$。

   事实上，若 $\mathcal{X}$ 有 M 个元素，则 $p(x)$ 与均匀分布 $\bar{p}(x) = 1/M$ 之间的 KL 散度满足 $D(p\|\bar{p}) = \log_2 M - H(p)$。结论由上面提到的 KL 散度性质得到。

4. 若 X, Y 是两个独立随机变量，即 $p_{X,Y}(x,y) = p_X(x)p_Y(y)$，则二者组成的序对的总熵等于 $H_X + H_Y$：

$$\begin{aligned} H_{X,Y} &= -\sum_{x,y} p(x,y)\log_2 p_{X,Y}(x,y) \\ &= -\sum_{x,y} p_X(x)p_Y(y)\big(\log_2 p_X(x) + \log_2 p_Y(y)\big) = H_X + H_Y. \end{aligned} \tag{1.11}$$

5. *对任意一对随机变量，一般有 $H_{X,Y} \leq H_X + H_Y$，这一结果可立即推广到 n 个变量。（证明可用 KL 散度 $D(p_1\|p_2)$ 的非负性，其中 $p_1 = p_{X,Y}$、$p_2 = p_X p_Y$。）

6. *复合事件的可加性。取一个有限事件集合 $\mathcal{X}$，将其分解为 $\mathcal{X} = \mathcal{X}_1 \cup \mathcal{X}_2$，其中 $\mathcal{X}_1 \cap \mathcal{X}_2 = \varnothing$。记 $q_1 = \sum_{x\in\mathcal{X}_1} p(x)$ 为 $\mathcal{X}_1$ 的概率，q_2 为 $\mathcal{X}_2$ 的概率。对每个 $x \in \mathcal{X}_1$，照常定义给定 $x \in \mathcal{X}_1$ 的条件概率 $r_1(x) = p(x)/q_1$；类似地定义 $r_2(x)$ 为给定 $x \in \mathcal{X}_2$ 时的条件概率。于是总熵可写作两部分之和：$H_X = -\sum_{x\in\mathcal{X}} p(x)\log_2 p(x) = H(q) + H(r)$，其中

$$H(q) = -q_1 \log_2 q_1 - q_2 \log_2 q_2, \tag{1.12}$$

$$H(r) = -q_1 \sum_{x\in\mathcal{X}_1} r_1(x)\log_2 r_1(x) - q_2 \sum_{x\in\mathcal{X}_1} r_2(x)\log_2 r_2(x). \tag{1.13}$$

   译注：式 (1.13) 的第二个求和下标按原文保留为 $\mathcal{X}_1$；结合上文 r_2 的定义和分解，须核查这里是否应为 $\mathcal{X}_2$。

   只要将 r_1, r_2 替换成其展开定义，证明就显然成立。这一性质解释为：与事件 x 的选择相关的平均信息具有可加性，它是选择子集所关联的信息 $H(q)$ 和子集内部选择事件所关联的信息 $H(r)$（按各子集的概率加权）之和。这是熵的主要性质，说明了为何可用它度量信息。事实上，这是条件熵所谓链式法则的一个简单例子，第 1.4 节还将进一步说明。

反过来，上述性质连同某些连续性和单调性假设，也可用于公理化地定义熵。

[3]译注：按原文写出的证明，若 q 在某些 $p > 0$ 的点上为零，$\mathbb{E}_q[p(X)/q(X)]$ 应按 q 的支集计算，可能小于 1；此时仍可得到非正上界。涉及 $q(x) > 0$ 而 $p(x) = 0$ 的点时，通常将相应散度视为 $+\infty$。

1.3 随机变量序列与熵率

在许多关心的情形中，我们会遇到生成随机变量序列 $\{X_t\}_{t\in\mathbb{N}}$ 的随机过程，其中每个变量都取值于同一有限空间 $\mathcal{X}$。我们用 $P_N(x_1,\dots,x_N)$ 表示前 N 个变量的联合概率分布。若 $A\subset\{1,\dots,N\}$ 是一个指标子集，记其补集为 $\bar{A}=\{1,\dots,N\}\backslash A$，并采用记号 $x_A=\{x_i:i\in A\}$ 和 $x_{\bar{A}}=\{x_i:i\in\bar{A}\}$。对 $\bar{A}$ 中的变量求和，得到 A 中变量的边缘分布：

$$P_A(x_A)=\sum_{x_{\bar{A}}}P_N(x_1,\dots,x_N). \tag{1.14}$$

例 1.7. 最简单的情形是各 X_t 相互独立。这意味着 $P_N(x_1,\dots,x_N)=p_1(x_1)p_2(x_2)\cdots p_N(x_N)$。如果所有分布 p_i 都相同，等于 p，则这些变量独立同分布，简称 *i.i.d.*，其联合分布为

$$P_N(x_1,\dots,x_N)=\prod_{t=1}^{N}p(x_i). \tag{1.15}$$

译注： 式 (1.15) 原文的乘积指标为 t、因子下标为 i，二者不一致；按上下文需核查因子下标是否应为 t，此处保留原式。

例 1.8. 如果随机变量序列 $\{X_t\}_{t\in\mathbb{N}}$ 满足

$$P_N(x_1,\dots,x_N)=p_1(x_1)\prod_{t=1}^{N-1}w(x_t\to x_{t+1}), \tag{1.16}$$

则称它为 *Markov* 链。这里 $\{p_1(x)\}_{x\in\mathcal{X}}$ 称为初始状态，$\{w(x\to y)\}_{x,y\in\mathcal{X}}$ 为链的转移概率。转移概率必须非负并满足归一化条件：

$$\sum_{y\in\mathcal{X}}w(x\to y)=1,\qquad \text{对任意}y\in\mathcal{X}. \tag{1.17}$$

译注： 式 (1.17) 的求和变量是 y，而原文又写“对任意 y”；从转移概率的归一化含义看，此处应核查是否应写“对任意 x”。原句照录。

当一列随机变量由某个过程产生时，直观上熵随变量数目 N 增长。这一直觉启发我们定义序列 $\{X_t\}_{t\in\mathbb{N}}$ 的熵率为

$$h_X=\lim_{N\to\infty}H_{X^N}/N, \tag{1.18}$$

前提是该极限存在。下列例子应能说明上述定义的意义。

例 1.9. 若 X_t 是分布为 $\{p(x)\}_{x\in\mathcal{X}}$ 的独立同分布随机变量，则熵的可加性给出

$$h_X=H(p)=-\sum_{x\in\mathcal{X}}p(x)\log p(x). \tag{1.19}$$

例 1.10. 设 $\{X_t\}_{t\in\mathbb{N}}$ 是初始状态为 $\{p_1(x)\}_{x\in\mathcal{X}}$、转移概率为 $\{w(x\to y)\}_{x,y\in\mathcal{X}}$ 的 *Markov* 链。记 $\{p_t(x)\}_{x\in\mathcal{X}}$ 为 X_t 的边缘分布，并假定下列极限存在且与初始条件无关：

$$p^*(x)=\lim_{t\to\infty}p_t(x). \tag{1.20}$$

正如我们将在第 4 章看到的，在转移概率 $\{w(x \to y)\}_{x,y\in\mathcal{X}}$ 满足相当温和的假设时，这确实成立。于是容易证明

$$h_X = -\sum_{x,y\in\mathcal{X}} p^*(x)w(x \to y)\log w(x \to y). \tag{1.21}$$

例如，设想以字母表 $\mathcal{X}$ 中的字母随机生成英文文本，采用由经验确定的转移概率 $w(x \to y)$，则式 (1.21) 给出英文熵的一个初步估计。但要生成看起来像英文的文本，需要更一般的过程，例如根据前 k 个字母 $x_t, x_{t-1}, \ldots, x_{t-k+1}$ 的值，通过转移概率 $w(x_t, x_{t-1}, \ldots, x_{t-k+1} \to x_{t+1})$ 生成新字母 x_{t+1}。计算相应的熵率很容易。取 $k = 4$ 时，每个字母的熵为 *2.8* 比特，远低于显然的上界 $\log_2 27$（*26* 个字母加空格符号），但这样生成的许多单词仍不是正确的英文单词。通过猜测实验得到的一些更好的英文熵估计约为 *1.3*。

1.4 相关变量与互熵

给定分别取值于 $\mathcal{X}$ 与 $\mathcal{Y}$ 的两个随机变量 X, Y，我们用 $p_{X,Y}(x, y)$ 表示其联合概率分布，简写为 $p(x, y)$；用 $p_{Y|X}(y \mid x)$ 表示给定 x 时变量 y 的条件概率分布，简写为 $p(y \mid x)$。读者应该熟悉经典的 Bayes 定理：

$$p(y \mid x) = p(x, y)/p(x). \tag{1.22}$$

当 X, Y 相互独立时，$p(y \mid x)$ 与 x 无关。当变量相关时，我们希望衡量它们的依赖程度：如果知道 x，能获得多少关于 y 的信息？条件熵与互熵的概念对此很有用。

定义条件熵 $H_{Y|X}$ 为分布 $p(y \mid x)$ 的熵对 x 的平均：

$$H_{Y|X} \equiv -\sum_{x\in\mathcal{X}} p(x)\sum_{y\in\mathcal{Y}} p(y \mid x)\log_2 p(y \mid x). \tag{1.23}$$

变量对 x, y 的总熵 $H_{X,Y} \equiv -\sum_{x\in\mathcal{X},y\in\mathcal{Y}} p(x, y)\log_2 p(x, y)$ 可以写成 x 的熵加上给定 x 时 y 的条件熵：

$$H_{X,Y} = H_X + H_{Y|X}. \tag{1.24}$$

在两个变量独立的简单情形中，$H_{Y|X} = H_Y$，且 $H_{X,Y} = H_X + H_Y$。衡量两个变量相关性的一种方式是*互熵* $I_{X,Y}$，定义为

$$I_{X,Y} \equiv \sum_{x\in\mathcal{X},y\in\mathcal{Y}} p(x, y)\log_2 \frac{p(x, y)}{p(x)p(y)}. \tag{1.25}$$

它与条件熵的关系为

$$I_{X,Y} = H_Y - H_{Y|X} = H_X - H_{X|Y}, \tag{1.26}$$

这说明 $I_{X,Y}$ 衡量了由于知道 y 而使 x 的不确定性减少了多少，且它对 x, y 对称。

命题 1.11. $I_{X,Y} \geq 0$。此外，$I_{X,Y} = 0$ 当且仅当 X, Y 独立。

证明. 写出 $-I_{X,Y} = \mathbb{E}_{x,y} \log_2[p(x)p(y)/p(x,y)]$。考虑概率分布为 $p(x,y)$ 的随机变量 $u = (x,y)$。由于对数函数是凹函数（即 $-\log$ 为凸函数），应用 Jensen 不等式 (1.6)，得到 $I_{X,Y} \geq 0$。 □

习题 1.5. 一大群朋友玩下列游戏（无电缆的电话）。第零个人等概率地选取数字 $X_0 \in \{0,1\}$，并在不让别人听见的情况下传给第一个人，依此类推。第一个人在不让其他人听见的情况下把数字传给第二个人。记从第 n 个人传给第 $n+1$ 个人的数字为 X_n。假设每一步都有一个人以概率 p 弄错并传出错误数字。第 n 个人对于第一个人的选择有多少信息？

我们可以用 $I_{X_0,X_n} \equiv I_n$ 来量化这一信息。一个简单计算表明 $I_n = 1 - H(p_n)$，其中 p_n 满足 $1 - 2p_n = (1-2p)^n$。特别地，当 $n \to \infty$ 时，

$$I_n = \frac{(1-2p)^{2n}}{2\log 2}\left[1 + O\big((1-2p)^{2n}\big)\right]. \tag{1.27}$$

沿着这一链，关于最初选择的“知识”呈指数下降。[4]

数据在传递或处理时，互熵会退化。这一点由下述命题量化。

命题 1.12 (数据处理不等式). *考虑 Markov 链 $X \to Y \to Z$（三个变量的联合概率可以写为 $p_1(x)w_2(x \to y)w_3(y \to z)$），则 $I_{X,Z} \leq I_{X,Y}$。特别地，若 Z 为 Y 的函数 $Z = f(Y)$，则施加 f 会使信息退化：$I_{X,f(Y)} \leq I_{X,Y}$。*

证明. 一般地，引入给定第三个变量时两个变量的条件互熵：$I_{X,Y|Z} = H_{X|Z} - H_{X,(YZ)}$。变量 X 与变量对 (YZ) 之间的互信息可作类似链式法则的分解：$I_{X,(YZ)} = I_{X,Z} + I_{X,Y|Z} = I_{X,Y} + I_{X,Z|Y}$。若 $X \to Y \to Z$ 为 Markov 链，在对 Y 的取值条件化后，X 与 Z 相互独立，故 $I_{X,Z|Y} = 0$。结论由 $I_{X,Y|Z} \geq 0$ 得到。[5] □

1.5 数据压缩

设想一个信息源产生符号序列 $X = \{X_1, \ldots, X_N\}$，这些符号取值于有限字母表 $\mathcal{X}$。假定信息源有一个概率模型，即各 X_i 是随机变量。我们希望以最紧凑的方式存储该信息源的一个给定实现 $x = \{x_1 \ldots x_N\}$ 中包含的信息。

这就是信源编码的基本问题。它不仅具有重要的实际意义，也很有启发性：它使我们能够以具体方式形式化与熵的定义相关的“信息”和“不确定性”直觉。由于熵将在全书中起关键作用，我们在此稍作绕行，讨论信源编码。

1.5.1 码字

首先需要明确“存储信息”的含义。因此，我们将随机变量 X 的一个信源码定义为映射 w：它将 $\mathcal{X}^N$ 中每个可能的信息序列关联到一个参考字母表上的字符串；我们假定参考字母表

[4]译注：上述渐近下降需要 $|1-2p| < 1$；当 $p = 0$ 或 $p = 1$ 时，传递可逆，互信息不随 n 衰减。原文没有在此处单独注明端点条件。

[5]译注：条件互熵在此按原文印为 $H_{X|Z} - H_{X,(YZ)}$；通常的定义为 $H_{X|Z} - H_{X|YZ}$。这两式一般并不相等，原文需核查。

为 $\{0,1\}$：[6]

$$w : \mathcal{X}^N \to \{0,1\}^*, \qquad x \mapsto w(x). \tag{1.28}$$

这里按照惯例，用 $\{0,1\}^*$ 表示任意长度二进制字符串的集合。w 的像中的任何二进制字符串都称为*码字*。

符号序列 $X_1 \ldots X_N$ 常常是更长数据流的一部分。压缩该数据流分三步进行：首先将数据流分成长度为 N 的块；然后使用 w 对各块分别编码；最后把码字拼接成一个新的（希望更紧凑的）数据流。如果原始数据流由块 $x^{(1)}, x^{(2)}, \ldots, x^{(r)}$ 组成，则编码过程的输出是 $w(x^{(1)}), \ldots, w(x^{(r)})$ 的拼接。一般来说，将此拼接结果切分成码字的方式可能不止一种，这会给希望恢复压缩数据的人带来麻烦。因此，我们要求码 w 使得码字的任意拼接都能无歧义地切分。满足这一性质的映射 w 称为*唯一可译码*。

如果对任意一对 $x, x' \in \mathcal{X}^N$，$w(x)$ 都不是 $w(x')$ 的前缀，那么唯一可译性一定成立。满足这一更强条件的码称为*瞬时码*（见图 1.2）。以下我们将重点讨论瞬时码，因为它们既实用又（稍微）容易分析。[7]

既然我们明确了如何用信源码存储信息，接下来需要为信源码引入性能指标。设 $l_w(x)$ 是字符串 $w(x)$ 的长度，则码的平均长度为

$$L(w) = \sum_{x \in \mathcal{X}^N} p(x)\, l_w(x). \tag{1.29}$$

例 1.13. 取 $N = 1$，考虑随机变量 X 取值于 $\mathcal{X} = \{1, 2, \ldots, 8\}$，概率分别为 $p(1) = 1/2$、$p(2) = 1/4$、$p(3) = 1/8$、$p(4) = 1/16$、$p(5) = 1/32$、$p(6) = 1/64$、$p(7) = 1/128$、$p(8) = 1/128$。考虑下表定义的两种码 w_1, w_2：

x	$p(x)$	$w_1(x)$	$w_2(x)$
1	1/2	000	0
2	1/4	001	10
3	1/8	010	110
4	1/16	011	1110
5	1/32	100	11110
6	1/64	101	111110
7	1/128	110	1111110
8	1/128	111	11111110

(1.30)

这两种码都是瞬时码。例如，对码 w_2，编码字符串 10001101110010 只能以一种方式切分，因为每个符号 *0* 都结束一个码字。因此它对应于序列 $x_1 = 2, x_2 = 1, x_3 = 1, x_4 = 3, x_5 = 4, x_6 = 1, x_7 = 2$。码 w_1 的平均长度是 $L(w_1) = 3$，码 w_2 的平均长度是 $L(w_2) = 247/128$。[8]注意，w_2 达到了更短的平均长度，因为它将最短的码字（即 *0*）分配给概率最大的符号（即 *1*）。

---

[6]内行读者会注意到，我们在此将讨论限制在“固定长度到可变长度”码。

[7]译注：原文此处对“任意一对”没有显式排除 $x = x'$；通常前缀码条件要求不同消息的码字满足相应条件，具体还取决于是否将字符串自身视为其前缀。

[8]译注：该数字按原文保留；由表中概率及 w_2 码字长度直接计算，平均长度为 255/128，而不是 247/128。

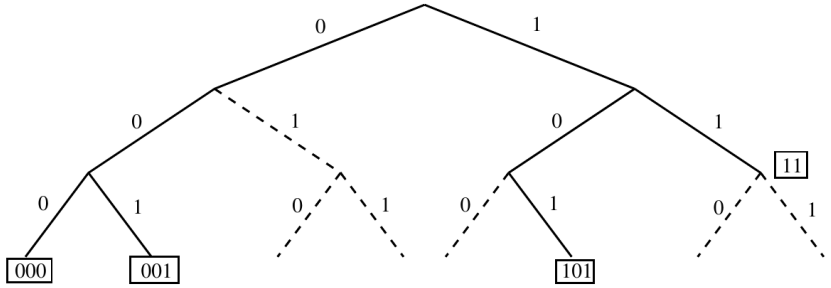


图 1.2: 一个瞬时信源码：将每个码字分配给二叉树的一个节点，使任一码字都不是另一码字的祖先。图中四个码字加了方框。图取自 Part A 草稿第 12 页。

例 1.14. *信源码的一种有用图示方法是绘制二叉树，并将每个码字与相应节点关联起来。在图 1.2 中，我们以这种方式表示 $|\mathcal{X}^N| = 4$ 的一个信源码。很容易看出该码确实是瞬时码：加框的码字中，没有任何一个是另一码字的祖先。给定码字序列时可立即切分。例如，序列 00111000101001 只能切分为*

$$001, \quad 11, \quad 000, \quad 101, \quad 001.$$

1.5.2 最优压缩与熵

假设我们对希望压缩的信源有 “完整的概率刻画”。该信源的 “最佳码” w 是什么？可以达到的最短平均长度是多少？

Shannon 在其著名的 1948 年论文中，通过将可达到的最佳平均长度与信源的熵联系起来，解决了这一问题（仅余一些小的细节）。按照 Shannon 的方法，我们假设知道信源的概率分布 $p(x)$，这就是 “完整的概率刻画” 的含义。此外，我们把 “最佳” 解释为 “具有最短的平均长度”。

定理 1.15. *设 L_N^* 为 $X = \{X_1, \ldots, X_N\}$ 的瞬时码所能达到的最短平均长度，H_X 为该变量的熵。则：*

1. 对任意 $N \geq 1$，

$$H_X \leq L_N^* \leq H_X + 1. \tag{1.31}$$

2. 若信源具有有限熵率 $h = \lim_{N\to\infty} H_X/N$，则

$$\lim_{N\to\infty} \frac{1}{N} L_N^* = h. \tag{1.32}$$

证明. 式 (1.31) 证明的基本思想是：如果码字过短，该码就不可能是瞬时码。Kraft 不等式使这一简单观察更加精确。对任意瞬时码 w，其长度 $l_w(x)$ 满足

$$\sum_{x\in\mathcal{X}^N} 2^{-l_w(x)} \leq 1. \tag{1.33}$$

将码字集合表示为二叉树上的叶节点，就容易证明这一事实（见图 1.2）。设 L_M 为最长码字的长度。考虑二叉树中第 L_M 代的全部 2^{L_M} 个可能节点，称它们为“后代”。如果信息 x 与第 l 代的一个码字关联，即 $l_w(x)=l$，由于该码是瞬时码，以此码字为根的树枝上就不能有其他码字。我们“擦去”相应的 2^{L_M-l} 个不能成为码字的后代。不同码字对应的被擦除后代子集互不重叠，因此被擦除后代的总数 $\sum_x 2^{L_M-l_w(x)}$ 必须小于或等于后代总数 2^{L_M}，这就建立了 Kraft 不等式。

反过来，对任何满足不等式 (1.33) 的一组长度 $\{l(x)\}_{x\in\mathcal{X}^N}$，至少存在一个码，其码字具有这些长度。一种可能的构造如下：考虑最小长度 $l(x)$，取第一个允许的长度为 $l(x)$ 的二进制序列作为 x 的码字。对次短长度重复这一操作，依此类推，直到所有码字均已构造。容易证明，只要满足式 (1.33)，这一过程就会成功。

因此，问题化为寻找一组码字长度 $l(x)=l^*(x)$，使平均长度 $L=\sum_x p(x)l(x)$ 在 Kraft 不等式 (1.33) 约束下最小。先假设 $l(x)$ 为实数，利用 Lagrange 乘子容易得到 $l(x)=-\log_2 p(x)$。这组最优长度通常无法实现，因为有些 $l(x)$ 不是整数；它给出的平均长度等于熵 H_X，从而得到式 (1.31) 的下界。为了构造一个长度为整数的实际码，我们采用

$$l^*(x)=\lceil -\log_2 p(x)\rceil. \tag{1.34}$$

这样的码满足 Kraft 不等式，其平均长度小于或等于 H_X+1，这就证明了式 (1.31) 的上界。

定理的第二部分是第一部分的直接推论。 □

在证明中构造的码通常称为 Shannon 码。对于长字符串（$N\gg 1$），它接近最优。然而，它一般并无理由达到最优。例如，如果只有一个 $p(x)$ 很小，就会给它分配一个很长的码字，尽管还存在更短的可用码字。值得知道的是，对给定信源 $\{X_1,\ldots,X_N\}$，存在最优码的显式构造，称为 Huffman 码。

乍看之下，定理 1.15 连同 Shannon 码的构造似乎完全解决了信源编码问题。但以下论述表明事实远非如此。

从计算角度看，上述编码过程并不实用。可以一次性构造该码并存储在某处，但这需要 $O(|\mathcal{X}|^N)$ 的内存。另一方面，也可以在每次编码字符串时重新构造该码，但这需要 $O(|\mathcal{X}|^N)$ 的时间。也可以使用同一个码，并在编码过程中采用更聪明一些的方法，但这不会带来显著改善。

从实际角度看，构造 Shannon 码需要准确知道信源的概率规律。假设你想压缩莎士比亚全集，那么为“莎士比亚”这个信源构造一个好的模型极其困难。更糟的是，当你最终得到这样一个模型时，它对压缩但丁或拉辛的作品几乎没有用处。幸运的是，在过去半个世纪里，信源编码在这两个方向上都取得了巨大进展。

1.6 数据传输

前面我们考虑了如何将信息编码到一个符号串中：我们使用的是比特，但任何有限字母表都同样适用。现在假设我们想要传递这一符号串。传输过程中，它可能受到某种噪声的破坏，这种噪声取决于传输所用的物理设备。可以通过向字符串添加冗余来减轻这一问题。冗余将用于纠正（一部分）传输错误，就像英语中的冗余可以用于纠正本书中的某些排字错误一样。这属

于信道编码领域。信息论的一个核心结果同样源自 Shannon 1948 年的开创性工作，它把冗余程度与无差错传输所能容忍的最大噪声程度联系起来。熵在这一结果中再次起关键作用。鉴于两个问题之间的对称性，这并不奇怪：在数据压缩中，人们希望减少数据冗余，而熵衡量能够达到的最终缩减；在数据传输中，人们希望向数据添加精心设计的冗余。

1.6.1 通信信道

通信系统的典型流程如图 1.3 所示。它适用于地面与卫星之间的通信、蜂窝电话，以及计算机硬盘中的存储等各种不同情形。Alice 想要向 Bob 发送消息 m。假设 m 为长度 M 比特的序列。该消息首先被编码成一个更长的 N 比特消息，记为 x，其中 $N > M$；增加的比特提供用于纠正传输错误的冗余。编码器是从 $\{0,1\}^M$ 到 $\{0,1\}^N$ 的映射。编码后的消息经过通信信道，信道输出消息 y。对于无噪声信道，只需有 $y = x$。在实际信道中，y 一般是与 x 不同的符号串；注意 y 甚至不一定是比特串。信道由转移概率 $Q(y \mid x)$ 描述：它是发送信号为 x 的条件下接收信号为 y 的概率。不同的物理信道由不同的 $Q(y \mid x)$ 函数描述。解码器接收消息 y，并由此推断所发送消息的估计 m'。

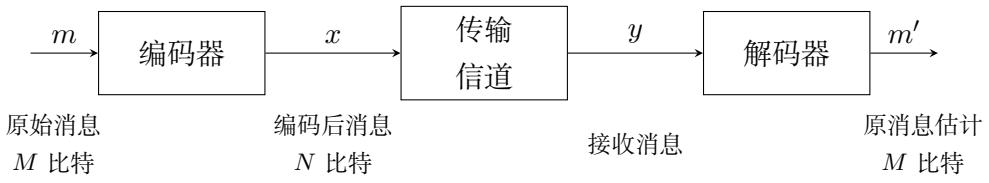


图 1.3: 通信设备的典型流程图。依 Part A 草稿图 1.3 重绘并翻译图中文字。

习题 1.6. 考虑下列具有插入的信道。当比特 x 输入信道时，以相同的概率 1/2 接收 x 或 $x0$。假设发送字符串 111110，则以概率 $2 \cdot 1/64$ 接收字符串 1111100（第 5 位或第 6 位发生错误都可以产生相同输出）。注意，该信道的输出是长度总不小于输入的比特串。

这种信道的一种简单编码容易构造：原消息中每个 0 用字符串 100 表示，每个 1 用 1100 表示。例如，编码为

$$01101 \mapsto 100110011001001100. \tag{1.35}$$

请读者定义解码算法并验证其有效性。

以下我们考虑无记忆信道。在这种情形中，对任意输入 $x = (x_1, \ldots, x_N)$，输出消息是来自字母表 $\mathcal{Y} \ni y_i$ 的 N 个字符组成的字符串 $y = (y_1, \ldots, y_N)$；$\mathcal{Y}$ 不一定是二进制的。对于无记忆信道，噪声对每个输入比特独立作用，即条件概率 $Q(y \mid x)$ 分解为

$$Q(y \mid x) = \prod_{i=1}^{N} Q(y_i \mid x_i), \tag{1.36}$$

且转移概率 $Q(y_i \mid x_i)$ 与 i 无关。

例 1.16（二元对称信道（BSC））. 输入 x_i 和输出 y_i 都取值于 $\{0,1\}$。该信道由一个数表征：输入比特被传成相反比特的概率 p。通常使用图 1.4 所示的图形表示。

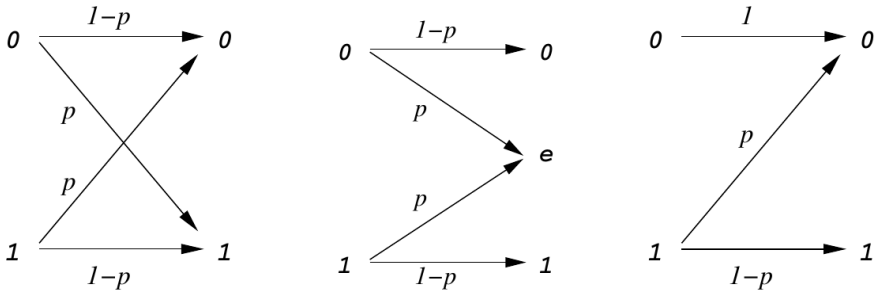


图 1.4: 三种通信信道。左：二元对称信道，传输中输出比特与输入相反的错误以概率 p 发生。中：二元擦除信道，输出 e 表示传输错误，其概率为 p。右：Z 信道，每当发送 1 时，以概率 p 发生错误。图取自 Part A 草稿第 16 页。

例 1.17 (二元擦除信道（BEC）)**.** 这里输入的一些比特被擦除，而非被改写：x_i 仍属于 $\{0,1\}$，但现在 y_i 属于 $\{0,1,e\}$，其中 e 表示擦除。在对称情形中，此信道由一个数描述，即比特被擦除的概率 p，见图 *1.4*。

例 1.18 (Z 信道)**.** 这里输出字母表仍为 $\{0,1\}$。此外，*0* 总是被正确传输，而 *1* 以概率 p 变成 *0*。该信道的名称来自它的图形表示，见图 *1.4*。

信道一个非常重要的特征是信道容量 C。它用变量 X（发送的比特）与 Y（接收的信号）的互熵 I_{XY} 定义为

$$C = \max_{p(x)} I_{XY} = \max_{p(x)} \sum_{x\in\mathcal{X}, y\in\mathcal{Y}} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)}. \tag{1.37}$$

回顾一下，I 衡量由于知道 y 而使 x 的不确定性减少了多少。容量 C 衡量信道能有多忠实：如果信道输出是纯噪声，x 与 y 不相关且 $C = 0$。在另一个极端，如果给定 x 时确定有 $y = f(x)$，则 $C = \max_{\{p(x)\}} H(p) = 1$ 比特。[9]容量的重要性将在第 1.6.3 节 Shannon 编码定理中变得清楚：该定理表明，C 刻画了信道中可以忠实传输的信息量。

例 1.19. *考虑翻转概率为 p 的二元对称信道。记信源发送 $x = 0$ 的概率为 q，发送 $x = 1$ 的概率为 $1 - q$。容易证明，当以相等概率发送 0 和 1（即 $q = 1/2$）时，式 (1.37) 中的互信息达到最大值。*

利用式 (1.37) 得到 $C = 1 - H(p)$ 比特，其中 $H(p)$ 是参数为 p 的 Bernoulli 过程的熵（如图 1.1 所示）。

例 1.20. *考虑错误概率为 p 的二元擦除信道。应用上述相同的论证，容易得到 $C = 1 - p$。*

习题 1.7. *计算 Z 信道的容量。*

1.6.2 纠错码

为了完整定义信道编码问题，我们仍需要确定信息源的行为。我们假定它产生一列无关联且无偏的比特。对于任何实际信息源，这一模型乍看可能非常粗糙。令人惊讶的是，Shannon

[9]译注：此处原文将确定性映射 $y = f(x)$ 的容量写为 1 比特；对二元输入，若 f 把两个输入映为同一输出，容量为 0。达到 1 比特还需 f 能区分两个输入。

的信源—信道分离定理保证，处理这种情形实际上不会损失一般性。

信源产生的比特序列被分成长度为 M 的块 $m_1, m_2, m_3, \ldots$。编码是从 $\{0,1\}^M \ni m$ 到 $\{0,1\}^N$ 的映射，其中 $N \geq M$。每个可能的 M 比特消息 m 都被映射到码字 $x(m)$，它是 N 维单位超立方体中的一个点。码字长度 N 也称为块长。共有 2^M 个码字，所有可能码字组成的集合称为*码本*。传送消息时，码字 x 以概率 $Q(y \mid x) = \prod_{i=1}^{N} Q(y_i \mid x_i)$ 被噪声破坏成 $y \in \mathcal{Y}^N$。输出字母表 $\mathcal{Y}$ 由信道决定。解码是从 $\mathcal{Y}^N$ 到 $\{0,1\}^M$ 的映射，它将接收到的消息 $y \in \mathcal{Y}^N$ 映射到一个可能的原消息 $m' = d(y) \in \{0,1\}^M$。

纠错码由编码 $x(m)$ 与解码 $d(y)$ 这两个函数共同定义。原始比特数与传输比特数之比

$$R = \frac{M}{N} \tag{1.38}$$

称为码的*码率*。码率衡量码的冗余：码率越小，加入的冗余越多，理论上就越可能纠正更多错误。

码在输入消息 m 上的块错误概率记为 $P_B(m)$，它是解码消息与发送消息不同的概率：

$$P_B(m) = \sum_{y} Q(y \mid x(m)) I(d(y) \neq m). \tag{1.39}$$

知道每个可能传送消息的错误概率，对码性能而言是一种极其详细的刻画。因此可以引入最大块错误概率

$$P_B^{\max} \equiv \max_{m \in \{0,1\}^M} P_B(m). \tag{1.40}$$

这相当于用码的“最坏情形”性能来刻画它。更乐观的观点是对输入消息取平均。由于我们假设所有消息等概率，引入平均块错误概率

$$P_B^{\mathrm{av}} \equiv \frac{1}{2^M} \sum_{m \in \{0,1\}^M} P_B(m). \tag{1.41}$$

由于这是纠错码极其常用的性能指标，以下我们不再特别说明，将其称为块错误概率并使用符号 P_B。

例 1.21 (重复码)**.** *考虑一个以概率 p 传错比特的 BSC。一个简单的码是把每个比特重复 k 次，其中 k 为奇数。形式上，$M = 1$、$N = k$，且*

$$x(0) = \underbrace{000\ldots00}_{k}, \tag{1.42}$$

$$x(1) = \underbrace{111\ldots11}_{k}. \tag{1.43}$$

例如，当 $k = 3$ 时，原始数据流 0110001 被编码为 000111111000000000111。一种可能的解码器将收到的序列解析为每组 k 个比特，再用这 k 个比特的多数规则求出消息 m'。在 $k = 3$ 的例子中，如果收到的三个比特是 111 或 110 的任意排列，则对应比特被判为 1，否则判为 0。例如，若信道输出为 000101111011000010111，解码得到 0111001。

这一 $k = 3$ 的重复码码率为 $R = M/N = 1/3$。容易证明块错误概率为 $P_B = p^3 + 3p^2(1-p)$，与信息比特无关。

显然，$k=3$ 的重复码只有在每组三个比特至多出现一个错误时才能纠正传输造成的差错。因此，在任何非零噪声下，块错误概率都保持非零。为改善此类码的性能，必须增大 k。一般 k 的错误概率为

$$P_B = \sum_{r=\lceil k/2 \rceil}^{k} \binom{k}{r} (1-p)^{k-r} p^r. \tag{1.44}$$

注意，当 k 有限且 $p>0$ 时，错误概率仍保持非零。要使 $P_B \to 0$，必须考虑 $k \to \infty$。由于码率 $R = 1/k$，因此错误概率趋于零的代价是通信码率也趋于零！[10]

幸运的是，正如我们将在下文看到的，存在好得多的码。

1.6.3 信道编码定理

考虑一个信道容量为式 (1.37) 中 C 的通信设备。Shannon 在 1948 年的奠基性论文中证明了下列定理。

定理 1.22. *对每个码率 $R<C$，存在一列码 $\{\mathcal{C}_N\}$，其块长为 N、码率为 R_N、块错误概率为 $P_{B,N}$，使得当 $N\to\infty$ 时 $R_N \to R$ 且 $P_{B,N}\to 0$。反过来，若一列码 $\{\mathcal{C}_N\}$ 满足 $N\to\infty$ 时 $R_N \to R$ 且 $P_{B,N}\to 0$，则 $R<C$。*

译注： 定理中的严格逆命题 $R<C$ 按原文保留；它一般不能排除等号。例如无噪声二元信道容量 $C=1$，以恒等映射编码可在 $R=1$ 时实现零错误。原文逆命题应核查是否应写作 $R\le C$。

实际中，对于长消息（即大的 N），当且仅当通信码率保持在容量以下时，才有可能可靠通信。这里不给出证明，而把它推迟到第 6 章和 “???”。[11]我们在此仅作一些定性说明，给出这一结果背后的直观思想。

首先，初次遇到这一结果时它相当令人惊讶。如上面的重复码例子所示，简单直接的码在任何非零噪声强度下通常都有有限错误概率。Shannon 定理表明，在保持有限通信码率的同时，可以使错误概率为零。

可以通过一种定性论证直观理解容量的作用，它使用了熵为 H 的随机变量 “典型地” 取 2^H 个值这一事实。对给定码字 $x(m)\in\{0,1\}^N$，信道输出 y 是一个熵为 $H_{y|x}=NH_{y|x}$ 的随机变量。这样的输出数目量级为 $2^{NH_{y|x}}$。要实现完美解码，需要解码函数 $d(y)$ 将每一个输出都映射回原消息 m。总体上，可能输出的典型数目为 2^{NH_y}，因此至多可以发送 $2^{N(H_y-H_{y|x})}$ 个码字。要使最大错误概率为零，就需要能够发送全部 $2^M=2^{NR}$ 个码字；只有在 $R<H_y-H_{y|x}<C$ 时才有可能。[12]

注释

有许多教材介绍概率论和信息论。Feller（1968）是一本标准概率教材。Shannon（1948）的原始论文被公认为信息论的奠基之作。Cover 和 Thomas（1991）的著作是一本非常好的现

[10]译注：$k\to\infty$ 是这里给出的必要方向，但就多数投票重复码而言，若 $p\ge 1/2$，单纯增大 k 并不会使错误概率趋零。

[11]译注：第二处章节引用在作者草稿中原印为三个问号，故如实保留，未推断缺失章节。

[12]译注：本段按作者原文作为定性论证保留；$H_{y|x}=NH_{y|x}$ 中同一记号同时用于块熵和单字符熵，且 C 是互信息的最大值，末尾严格不等号和相关典型性条件需核查。

代入门书；读者可以在其中找到本章未讨论的 Huffman 码，以及信源编码中的更高级主题。

我们没有证明第 1.2 节列出的六条性质实际上提供了熵的另一种（公理化）定义。有兴趣的读者可参阅 Csiszár 和 Körner（1981）。Gallager（1968） 是一本高级信息论著作，其中用了大量篇幅讨论编码理论。MacKay（2002） 近期出版的内容丰富的书讨论了编码理论与统计推断和机器学习之间的关系。

信息论的熵定义已用于许多语境，它可以作为统计力学的基础概念。Balian（1992） 讨论了这种方法。

第二章　统计物理与概率论

科学最伟大的成就之一，是认识到物质由少数几种简单的基本成分构成。这一结果似乎与我们的经验形成鲜明对比：无论在简单的感知层面，还是通过更精细的科学经验，我们接触到的物质状态种类都不断增加，且性质各异。统计物理（以及更广义的、凝聚态物理的一个大分支）的宏大目标，就是理解这种多样性。它力图解释，当大量相同的基本成分能够相互作用时，复杂行为如何涌现。

例如，我们经历过水的三种不同状态：固态、液态和气态。在不同状态之间转变时，水分子及其相互作用并不改变。理解相同的相互作用如何产生定性不同的宏观状态，以及什么支配状态之间的转变，是统计物理的核心课题。

统计物理的基础依赖两个重要步骤。第一步是从物理学的确定性定律（如 Newton 定律）转向概率描述。其思想是，精确知道宏观系统中每个分子的运动对于理解整个系统并非必要：相反，可以假设微观动力学由于其混沌性，允许纯概率描述。对这一步的详细论证仅在少数具体情形中得到。这里我们将绕开对此作出论证的任何尝试，直接采用纯概率观点，作为统计物理的一条基本假设。

第二步从概率描述出发，通过某种大数定律在宏观层面重新得到确定性。我们都知道，水在摄氏 100 度（大气压下）沸腾，或其密度（摄氏 25 度、大气压下）为 $1\,\mathrm{g/cm^3}$。这些现象的规律性与支配水分子运动的确定性定律无关，而是由于任何宏观系统都涉及大量粒子，涨落被“平均掉”了。我们将在第 2.4 节讨论这类现象，并在第 4 章更数学化地加以讨论。

本章的目标是面向具有数学背景的非物理学读者介绍该学科最基本的概念。我们采用较为受限的观点：只讨论经典统计物理，而非量子统计物理，并基本将它描述为概率论的一个分支（第 2.1–2.3 节）。第 2.4 节聚焦大系统，强调统计物理方法在这一范围内特别有意义。理论统计物理常常处理真实材料的高度理想化数学模型。事实上，最有趣、也最具挑战性的任务是理解这类系统的定性行为。为此，可以从模型的数学描述中丢弃任何“无关紧要”的微观细节。第 2.5 节通过引入 Ising 模型，以铁磁性为案例说明这一建模过程。可以说，人们对 Ising 铁磁体的理论理解已经相当深入；但对 Ising 自旋玻璃，情况要困难得多。第 2.6 节简要预览这一迷人的主题。

2.1　Boltzmann 分布

对物理系统进行概率描述的基本要素是：

- 一个构型空间 $\mathcal{X}$。应将 $x \in \mathcal{X}$ 看作对所研究系统状态的完整微观确定。我们并不关心为建立统计物理形式体系而定义 $\mathcal{X}$ 所需的最一般数学结构。事实上，全书只考虑两类非常

简单的构型空间：(i) 有限集合；(ii) 光滑、紧致的有限维流形。如果系统包含 N 个 “粒子”，其构型空间是乘积空间：

$$\mathcal{X}^N = \underbrace{\mathcal{X} \times \cdots \times \mathcal{X}}_{N}. \tag{2.1}$$

系统构型形如 $x = (x_1, \ldots, x_N)$。每个坐标 $x_i \in \mathcal{X}$ 用来表示一个粒子的状态（位置、取向等）。除少数例子外，我们将着重讨论 (i) 型构型空间，因此将对 $\mathcal{X}$ 采用离散空间记号。推广到连续构型空间在多数情形下直观上是清楚的，尽管可能出现技术困难。

- 一组可观测量，即构型空间上的实值函数 $O : x \mapsto O(x)$。如果 $\mathcal{X}$ 是流形，我们将只考虑作为构型 x 的光滑函数的可观测量。可观测量是可以通过实验测量的物理量，至少原则上如此。

- 在所有可观测量中，能量函数 $E(x)$ 具有特殊地位。当系统由 N 个粒子组成时，能量函数一般是只涉及少数粒子的各项之和。形如

$$E(x) = \sum_{i=1}^{N} E_i(x_i) \tag{2.2}$$

的能量函数对应于无相互作用系统。形如

$$E(x) = \sum_{i_1,\ldots,i_k} E_{i_1,\ldots,i_k}(x_{i_1}, \ldots, x_{i_k}) \tag{2.3}$$

的能量称为 k 体相互作用。一般而言，能量包含一些 k 体相互作用部分，其中 $k \in \{1, 2, \ldots, K\}$。真实物理系统的一个重要特点是，即使粒子数 N 很大，K 也从不是一个很大的数（通常 $K = 2$ 或 3）。所有可测可观测量也具有相同性质。然而，在这里使用的一般数学表述中，能量可以是 $\mathcal{X}$ 上的任意实值函数。

一旦固定构型空间 $\mathcal{X}$ 和能量函数，系统处于构型 x 的概率 $p_\beta(x)$ 由 Boltzmann 分布给出：

$$p_\beta(x) = \frac{1}{Z(\beta)} e^{-\beta E(x)}, \qquad Z(\beta) = \sum_{x \in \mathcal{X}} e^{-\beta E(x)}. \tag{2.4}$$

实参数 $T = 1/\beta$ 是温度，而 β 称为逆温度。[1]归一化常数 $Z(\beta)$ 称为配分函数。注意，式 (2.4) 实际定义的是 Boltzmann 分布相对于某个参考测度的密度。如果 $\mathcal{X}$ 离散，参考测度通常为计数测度；如果 $\mathcal{X}$ 连续，通常为 Lebesgue 测度。习惯上用尖括号表示对 Boltzmann 测度的期望值：可观测量 $O(x)$ 的期望值 $\langle O(x) \rangle$ 也称其 Boltzmann 平均，由下式给出：

$$\langle O \rangle = \sum_{x \in \mathcal{X}} p_\beta(x) O(x) = \frac{1}{Z(\beta)} \sum_{x \in \mathcal{X}} e^{-\beta E(x)} O(x). \tag{2.5}$$

例 2.1. 基本粒子的一个内禀性质是自旋。对于 “自旋 1/2” 粒子，自旋 σ 只取两个值：$\sigma = \pm 1$。一个局域化的自旋 1/2 粒子，其唯一自由度是自旋，由 $\mathcal{X} = \{+1, -1\}$ 描述，称为一个 *Ising* 自旋。磁场 B 中，该自旋处于状态 $\sigma \in \mathcal{X}$ 时的能量为

$$E(\sigma) = -B\sigma. \tag{2.6}$$

[1]在大多数统计物理书中，温度定义为 $T = 1/(k_B\beta)$，其中 k_B 是称为 Boltzmann 常数的常数，其数值由历史原因决定。这里我们选择简单的 $k_B = 1$，相当于对温标作特殊选择。

在状态 σ 找到该自旋的 *Boltzmann* 概率为

$$p_\beta(\sigma) = \frac{1}{Z(\beta)} e^{-\beta E(\sigma)}, \qquad Z(\beta) = e^{-\beta B} + e^{\beta B} = 2\cosh(\beta B). \tag{2.7}$$

自旋的平均值称为磁化强度：

$$\langle \sigma \rangle = \sum_{\sigma \in \{1,-1\}} p_\beta(\sigma)\sigma = \tanh(\beta B). \tag{2.8}$$

高温 $T \gg |B|$ 时磁化强度很小；低温时磁化强度接近其最大值，当 $B > 0$ 时 $\langle \sigma \rangle = 1$。第 *2.5* 节将讨论多个 *Ising* 自旋及一些更复杂的能量函数所产生的行为。

例 2.2. 某些自旋变量可以具有更大的可能取值空间。例如，具有 q 个状态的 *Potts* 自旋取值于 $\mathcal{X} = \{1, 2, \ldots, q\}$。在强度为 h、指向 $r \in \{1, \ldots, q\}$ 方向的磁场中，*Potts* 自旋的能量为

$$E(\sigma) = -B\delta_{\sigma,r}. \tag{2.9}$$

在这种情况下，自旋沿场方向的平均值为

$$\langle \delta_{\sigma,r} \rangle = \frac{\exp(\beta B)}{\exp(\beta B) + (q-1)}. \tag{2.10}$$

译注： 原文文字将场强记为 h，但紧随其后的公式使用 B；这里分别照录，二者的对应需核查。

例 2.3. 考虑封闭容器内的单个水分子，例如在一个瓶子里。水分子 H_2O 本身已经是相当复杂的对象。作为第一近似，我们可以忽略其结构，把它建模为瓶内的一个点。于是构型空间简化为

$$\mathcal{X} = \text{BOTTLE} \subset \mathbb{R}^3, \tag{2.11}$$

其中 BOTTLE 表示由容器界定的 $\mathbb{R}^3$ 区域。注意，这种描述在微观尺度上并不十分准确。

瓶子精确形状的描述可能相当复杂。另一方面，假定该分子处于所有位置的概率相等是一个良好近似：能量与粒子位置 $x \in \text{BOTTLE}$ 无关。于是

$$p(x) = \frac{1}{Z}, \qquad Z = |\mathcal{X}|, \tag{2.12}$$

粒子位置的 *Boltzmann* 平均 $\langle x \rangle$ 是瓶子的几何重心。

例 2.4. 假定上例中所有构型等概率时，我们忽略了重力对水分子的作用。在重力存在时，位于 x 的水分子具有能量

$$E(x) = w\ \mathrm{he}(x), \tag{2.13}$$

其中 $\mathrm{he}(x)$ 是位置 x 对应的高度，w 是由地球引力决定的正的常数，与分子质量成正比。给定瓶子中的两点 x, y，在两位置找到粒子的概率之比为

$$\frac{p_\beta(x)}{p_\beta(y)} = \exp\{-\beta w[\mathrm{he}(x) - \mathrm{he}(y)]\}. \tag{2.14}$$

对于室温 *20* 摄氏度（$T = 293$ 开尔文）下的水分子，有 $\beta w \approx 7 \times 10^{-5}\,\mathrm{m}^{-1}$。取瓶底一点 x 和高度为 *20 cm* 的一点 y，在 x “附近” 找到水分子的概率约为在 y “附近” 概率的 *1.000014* 倍。对于质量约为水分子 2×10^6 倍的烟草花叶病毒，该比值为 $p_\beta(x)/p_\beta(y) \approx 1.4 \times 10^{12}$，非常大。对于一粒沙子，该比值大到我们从来不会观察到它漂浮在 y 的附近。注意，虽然这些概率密度之比容易计算，配分函数、因而概率密度的绝对值可能更难估计，具体取决于瓶子的形状。

例 2.5. 在许多重要情形中，给定构型空间 $\mathcal{X}$ 及其上定义的随机动力学，我们最感兴趣的概率分布是平稳态 $p_{\rm st}(x)$，并假设它是唯一的。为简单起见，可以考虑有限空间 $\mathcal{X}$ 及转移概率为 $\{w(x\to y)\}$ 的离散时间 *Markov* 链；我们将在第 *4* 章回顾有关 *Markov* 链的一些基本定义。有时，转移率对于任意一对构型 $x,y\in\mathcal{X}$ 满足关系

$$f(x)w(x\to y)=f(y)w(y\to x), \tag{2.15}$$

其中 $f(x)$ 是某个正函数。正如我们将在第 *4* 章看到的，当这一称为细致平衡的条件成立时，连同另外几个技术条件，平稳态具有式 (2.4) 的 *Boltzmann* 形式，且 $e^{-\beta E(x)}=f(x)$。

习题 2.1. 作为上一例的一个具体实现，考虑一个 8×8 国际象棋棋盘及其上的一个特殊棋子。在每个时间步，该棋子以概率 1/2 原地不动，或以概率 1/2 随机移动到相邻位置之一。这个过程是否满足条件 (2.15)？棋盘上的哪些位置具有较低（或较高）的“能量”？计算配分函数。

从纯概率观点看，人们可能会问：为什么要费心将分布 $p_\beta(x)$ 分解为 $e^{-\beta E(x)}$ 和 $1/Z(\beta)$ 两个因子？当然，将 Boltzmann 因子 $e^{-\beta E(x)}$ 写成指数形式的动机基本来自物理学，在物理学中人们知道能量的形式，可以是精确的，也可以是在一定近似程度下的形式。这也解释了为什么使用逆温度 β；毕竟总可以重新定义能量函数，使 $\beta=1$。

不过，需要强调的是，即使采用数学观点，并且我们只对某个对应于特定温度值的具体分布 $p(x)$ 感兴趣，把它嵌入一个单参数族往往仍很有启发性，Boltzmann 表达式 (2.4) 就是这样做的。事实上，式 (2.4) 在若干有趣情形之间平滑插值。当 $\beta\to 0$（高温极限）时，恢复均匀概率分布

$$\lim_{\beta\to 0} p_\beta(x)=\frac{1}{|\mathcal{X}|}. \tag{2.16}$$

概率 $p_\beta(x)$ 和可观测量期望 $\langle O(x)\rangle$ 均可在 $\beta=0$ 附近表示为收敛的 Taylor 展开。对于小 β，可以将 Boltzmann 分布看作对原分布的“软化”。

在 $\beta\to\infty$（低温极限）时，Boltzmann 分布集中在原分布的全局最大值上。更准确地说，若对任意 $x\in\mathcal{X}$ 都有 $E(x)\geq E(x_0)$，则称 $x_0\in\mathcal{X}$ 为基态。能量的最小值 $E_0=E(x_0)$ 称为基态能量。我们用 $\mathcal{X}_0$ 表示基态集合。很容易证明

$$\lim_{\beta\to\infty} p_\beta(x)=\frac{1}{|\mathcal{X}_0|}I(x\in\mathcal{X}_0), \tag{2.17}$$

其中 $x\in\mathcal{X}_0$ 时 $I(x\in\mathcal{X}_0)=1$，否则为 0。物理学家常用行话概括上述行为：“低能构型主导”系统在低温时的行为。[2]

2.2 热力学势

Boltzmann 分布 (2.4) 的若干性质可以方便地通过热力学势概括。这些量是温度 $1/\beta$ 以及定义能量 $E(x)$ 的各种参数的函数。最重要的热力学势是自由能：

$$F(\beta)=-\frac{1}{\beta}\log Z(\beta), \tag{2.18}$$

[2]译注：式 (2.17) 照原文保留；这里的基态均匀分布结论直接适用于有限离散构型空间，推广到连续空间需另行考虑参考测度、极小点和极限意义。

其中 $Z(\beta)$ 是式 (2.4) 中已定义的配分函数。式 (2.18) 的因子 $-1/\beta$ 基本是由历史原因引入的。在计算中，有时使用自由熵[3] $\Phi(\beta) = -\beta F(\beta) = \log Z(\beta)$ 更方便。

另外两个热力学势由自由能导出，即内能 $U(\beta)$ 与正则熵 $S(\beta)$：

$$U(\beta) = \frac{\partial}{\partial\beta}(\beta F(\beta)), \qquad S(\beta) = \beta^2 \frac{\partial F(\beta)}{\partial\beta}. \tag{2.19}$$

通过直接计算，得到已定义热力学势的下列恒等式：

$$F(\beta) = U(\beta) - \frac{1}{\beta}S(\beta) = -\frac{1}{\beta}\Phi(\beta), \tag{2.20}$$

$$U(\beta) = \langle E(x)\rangle, \tag{2.21}$$

$$S(\beta) = -\sum_x p_\beta(x)\log p_\beta(x), \tag{2.22}$$

$$-\frac{\partial^2}{\partial\beta^2}(\beta F(\beta)) = \langle E(x)^2\rangle - \langle E(x)\rangle^2. \tag{2.23}$$

式 (2.22) 可以表述为：正则熵就是第 1 章所定义的 Boltzmann 分布的 Shannon 熵。因此 $S(\beta) \geq 0$。式 (2.23) 表明自由熵是温度的凸函数。最后，式 (2.21) 说明为什么把 $U(\beta)$ 称为“内能”。[4]

为直观理解这些定义的含义，让我们重新考虑上一节讨论过的高温和低温极限。高温极限 $\beta \to 0$ 下，得到

$$F(\beta) = -\frac{1}{\beta}\log|\mathcal{X}| + \langle E(x)\rangle_0 + \Theta(\beta), \tag{2.24}$$

$$U(\beta) = \langle E(x)\rangle_0 + \Theta(\beta), \tag{2.25}$$

$$S(\beta) = \log|\mathcal{X}| + \Theta(\beta). \tag{2.26}$$

符号 Θ 表示“具有……量级”；其精确定义见附录。[5]这些公式的解释很直接：高温下，系统处于任何可能构型的概率相近（$\beta = 0$ 时概率完全相同）；熵计数了可能构型的数目；内能恰是构型在均匀概率分布下的平均能量。尽管高温展开式 (2.24)–(2.26) 对离散和连续构型空间 $\mathcal{X}$ 具有相同形式，低温情形必须更谨慎。若 $\mathcal{X}$ 有限，我们可以有意义地将能隙 $\Delta E > 0$ 定义为

$$\Delta E = \min\{E(y) - E_0 : y \in \mathcal{X} \setminus \mathcal{X}_0\}, \tag{2.27}$$

其中回顾一下，E_0 表示基态能量。根据这一定义，得到

$$F(\beta) = E_0 - \frac{1}{\beta}\log|\mathcal{X}_0| + \Theta(e^{-\beta\Delta E}), \tag{2.28}$$

$$E(\beta) = E_0 + \Theta(e^{-\beta\Delta E}), \tag{2.29}$$

$$S(\beta) = \log|\mathcal{X}_0| + \Theta(e^{-\beta\Delta E}). \tag{2.30}$$

[3]与其他热力学势不同，$\Phi(\beta)$ 没有公认的统一名称；由于这一势非常有用，我们采用“自由熵”这一名称。

[4]译注：式 (2.23) 直接给出的是 $\Phi = \log Z$ 对逆温度 β 的凸性，而非一般情况下对温度 $T = 1/\beta$ 的凸性。非负熵的结论直接适用于离散概率分布；连续空间中相对于参考测度的微分熵可以为负。原文表述在正文照录。

[5]译注：原文在此处的附录交叉引用未解析，未给出具体附录编号。若将 Θ 按通常的严格双侧渐近界理解，上述各项可能因为前导系数为零而不满足所示量级；例如有限离散体系中熵对 β 的一阶修正为零。

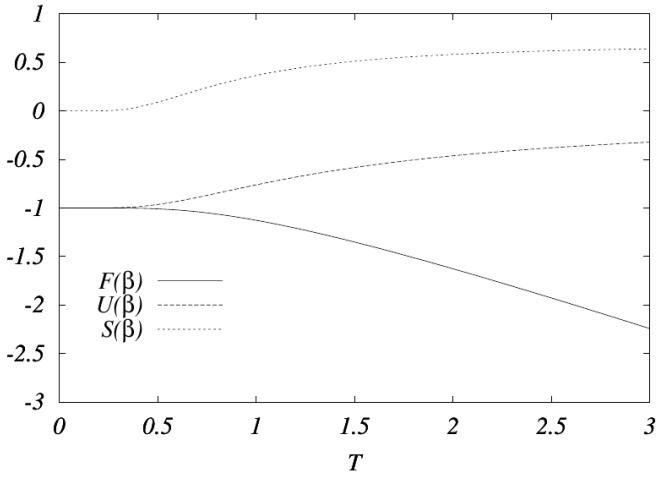


图 2.1: 两能级系统的热力学势随温度 $T = 1/\beta$ 的变化，其中 $\epsilon_1 = -1$、$\epsilon_2 = +1$。图取自 Part A 草稿第 29 页。

译注： 式 (2.29) 的内能按原文记为 $E(\beta)$，前面使用的符号是 $U(\beta)$。此外，若严格按双侧渐近界解释 Θ，自由能修正通常含 $1/\beta$ 因子，而熵修正通常含 β 因子；原文这些量级的记号需进一步核查。

其解释是：低温下，系统以相等概率处于任一基态，而不处于其他状态。熵再次计数可用构型的数目，而内能是它们的平均能量；这些能量都等于基态能量。

习题 2.2 (两能级系统)**.** 这是最简单的非平凡例子：$\mathcal{X} = \{1, 2\}$，$E(1) = \epsilon_1$、$E(2) = \epsilon_2$。不失一般性，假设 $\epsilon_1 < \epsilon_2$。它可以用作许多物理系统的数学模型，例如上面讨论过的自旋 1/2 粒子。

推导下列热力学势结果，其中 $\Delta = \epsilon_2 - \epsilon_1$ 是能隙：

$$F(\beta) = \epsilon_1 - \frac{1}{\beta}\log(1 + e^{-\beta\Delta}), \tag{2.31}$$

$$U(\beta) = \epsilon_1 + \frac{e^{-\beta\Delta}}{1 + e^{-\beta\Delta}}\Delta, \tag{2.32}$$

$$S(\beta) = \frac{e^{-\beta\Delta}}{1 + e^{-\beta\Delta}}\beta\Delta + \log(1 + e^{-\beta\Delta}). \tag{2.33}$$

这些函数的行为如图 *2.1* 所示。读者可以求出其渐近形式，并检查上面给出的一般高温和低温行为。

习题 2.3. 回到上一节的例子：把一个水分子建模为瓶子中的点。进一步考虑瓶子为圆柱形的情况，其底面 $B \subset \mathbb{R}^2$ 的面积为 $|B|$，高度为 d。

利用能量函数 (2.13)，推导下列热力学势的显式表达式：

$$F(\beta) = -\frac{1}{\beta}\log|B| - \frac{1}{\beta}\log\frac{1 - e^{-\beta wd}}{\beta w}, \tag{2.34}$$

$$U(\beta) = \frac{1}{\beta} - \frac{wd}{e^{\beta wd} - 1}, \tag{2.35}$$

$$S(\beta) = \log|Bd| + 1 - \frac{\beta wd}{e^{\beta wd} - 1} - \log\left[\frac{\beta wd}{1 - e^{-\beta wd}}\right]. \tag{2.36}$$

注意,内能公式可用于计算分子的平均高度 $\langle \mathrm{he}(x)\rangle = U(\beta)/w$。这是能量定义 (2.13) 和式 (2.21) 的结果。代入正确的常数 w，可发现平均高度只有在温度低于 3.2 K 时才降到瓶高 $d = 20\,\mathrm{cm}$ 的 49.99% 以下。

利用式 (2.34)–(2.36)，可以得到相同量在低温下的展开：

$$F(\beta) = -\frac{1}{\beta}\log\left[\frac{|B|}{\beta w}\right] + \Theta(e^{-\beta w d}), \tag{2.37}$$

$$U(\beta) = \frac{1}{\beta} + \Theta(e^{-\beta w d}), \tag{2.38}$$

$$S(\beta) = \log\left[\frac{|B|e}{\beta w}\right] + \Theta(e^{-\beta w d}). \tag{2.39}$$

这里 $\mathcal{X}$ 是连续的，且能量没有能隙。但这些结果可以作如下理解：低温下，分子被限制在瓶底上方高度量级为 $1/(\beta w)$ 的一层内，因此占据大小为 $|B|/(\beta w)$ 量级的体积。其熵近似由这一体积的对数给出。

习题 2.4. 重新考虑上例，假设瓶子有不同的形状，例如半径为 R 的球。在这种情况下，精确算出热力学势的显式表达式比较困难，但容易求出低温展开。对熵，在大 β 时有

$$S(\beta) = \log\left[\frac{2\pi e^2 R}{\beta^2 w^2}\right] + \Theta(1/\beta). \tag{2.40}$$

读者应尝试理解这一结果与式 (2.39) 的差别，并像前一例那样给出直观解释。物理学家说，低温热力学势揭示了系统的“低能结构”。

2.3 涨落耗散关系

能量函数常常光滑地依赖某些实参数。这些参数可能与研究某一物理系统的实验条件有关，也可能与某些基本物理量有关。例如，重力场中水分子的能量（见式 (2.13)）依赖分子自身的重量 w。虽然在物理世界中它是一个常数，但在理论处理中把它视为可调参数是有用的。

因此，考虑光滑依赖某个参数 λ 的能量函数 $E_\lambda(x)$ 是有意义的。它在 $\lambda = \lambda_0$ 附近容许如下 Taylor 展开：

$$E_\lambda(x) = E_{\lambda_0}(x) + (\lambda - \lambda_0)\left.\frac{\partial E}{\partial \lambda}\right|_{\lambda_0}(x) + O((\lambda-\lambda_0)^2). \tag{2.41}$$

自由能和其他热力学势在 λ_0 附近对 λ 的依赖，很容易与能量函数自身的显式依赖联系起来。考虑配分函数，将其展开到 $\lambda - \lambda_0$ 的一阶：

$$\begin{aligned} Z(\lambda) &= \sum_x \exp\left(-\beta\left[E_{\lambda_0}(x) + (\lambda-\lambda_0)\left.\frac{\partial E}{\partial\lambda}\right|_{\lambda_0}(x) + O((\lambda-\lambda_0)^2)\right]\right) \\ &= Z(\lambda_0)\left[1 - \beta(\lambda-\lambda_0)\left\langle \left.\frac{\partial E}{\partial\lambda}\right|_{\lambda_0}\right\rangle_0 + O((\lambda-\lambda_0)^2)\right], \end{aligned} \tag{2.42}$$

其中 $\langle\cdot\rangle_0$ 表示对 $\lambda = \lambda_0$ 时的 Boltzmann 分布取期望。

这表明自由熵满足

$$\left.\frac{\partial \Phi}{\partial\lambda}\right|_{\lambda_0} = -\beta\left\langle \left.\frac{\partial E}{\partial\lambda}\right|_{\lambda_0}\right\rangle_0. \tag{2.43}$$

还可以考虑一般可观测量 $A(x)$ 的期望对 λ 的依赖。再次使用 Taylor 展开，得到

$$\left.\frac{\partial\langle A\rangle_\lambda}{\partial\lambda}\right|_{\lambda_0} = -\beta\left\langle A;\left.\frac{\partial E}{\partial\lambda}\right|_{\lambda_0}\right\rangle_0, \tag{2.44}$$

其中 $\langle A;B\rangle$ 表示连通关联函数：$\langle A;B\rangle = \langle AB\rangle - \langle A\rangle\langle B\rangle$。式 (2.23) 给出了这一关系的一个特例。[6]

结果 (2.44) 具有重要的实际后果与许多推广。设想你有一套实验装置，可以调节某个参数 λ，例如气体压强、作用于材料的磁场或电场，同时监测可观测量 $A(x)$，例如气体体积、材料的极化强度或磁化强度。式 (2.44) 左侧是系统对可调参数无穷小变化的响应；右侧则是“未受扰动”系统中的某个关联函数。一种可能的应用是监测系统对外部扰动的响应，以测量系统内的关联。这种关联与响应之间的关系称为*涨落耗散关系*。

2.4 热力学极限

统计物理的主要目的是理解大量简单成分——原子、分子等——聚集在一起时的宏观行为，其中 $N \gg 1$。

具体来说，考虑瓶中的几滴水。系统的一个构型由瓶中所有 H_2O 分子的位置与取向给出。在这种情形中，$\mathcal{X}$ 是单个分子的位置和取向的集合，而 N 通常为 10^{23} 量级；更准确地说，18 克水约含 $6\cdot 10^{23}$ 个分子。这样一个巨大的数促使物理学家关注 $N\to\infty$ 的极限，也称为*热力学极限*。

如下述例子所示，当 N 很大时，热力学势通常与 N 成正比。因此引入强度型热力学势。用 $F_N(\beta)$、$U_N(\beta)$、$S_N(\beta)$ 表示包含 N 个“粒子”的系统的自由能、内能和正则熵。自由能密度定义为

$$f(\beta) = \lim_{N\to\infty} F_N(\beta)/N, \tag{2.45}$$

前提是该极限存在。[7]类似地定义能量密度 $u(\beta)$ 和熵密度 $s(\beta)$。

相当一般地，自由能 $F_N(\beta)$ 在实 β 轴附近是解析函数。这是因为 $Z(\beta)$ 在整个复 β 平面解析，并且对于实 β 严格为正。一个非常有意义的问题是：假设极限 (2.45) 存在，热力学极限中是否仍保留解析性？只要自由能密度 $f(\beta)$ 非解析，就称发生了*相变*。由于自由熵密度 $\phi(\beta) = -\beta f(\beta)$ 是凸的，只要自由能密度存在，它就必然连续。[8]

在最简单的情形中，非解析性出现在孤立点。设 β_c 是这样一个点，常见的奇异性有两种：

- 自由能密度连续，但其对 β 的导数在 β_c 处不连续。这种奇异性称为*一级相变*。
- 自由能及其一阶导数连续，但其二阶导数在 β_c 处不连续。这称为*二级相变*。

也可以沿相同思路定义更高阶的相变。

---

[6]译注：式 (2.44) 中的 $A(x)$ 按原文视为不显含 λ；若可观测量本身也依赖 λ，求导时还须计入其显式导数。

[7]这一极限通常存在，至少在粒子之间的力随粒子间距离增大而衰减得足够快时如此。

[8]译注：原文对有限系统解析性和极限连续性的表述按原句保留；连续构型空间、配分函数的复延拓以及 $\beta=0$ 等边界情形需要各自的可积性和定义域条件。

相变除了是有趣的数学现象之外，还对应于底层物理系统的定性变化。例如，在正常大气压下水于摄氏 100 度转变为水蒸气，在数学上被建模为上述意义下的一级相变。本书相当大的部分将研究许多不同系统中的相变，其中相互作用的“粒子”可以是信息比特或图的顶点上的占据数等各种对象。

当 N 增长时，构型空间的体积呈指数增长：$|\mathcal{X}^N| = |\mathcal{X}|^N$。当然，在 Boltzmann 分布下，并非所有构型都同等重要：能量较低的构型有更大的概率。因此重要的是给定能量下的构型数。这一信息编码在系统的能谱中：

$$\mathcal{N}_\Delta(E) = |\Omega_\Delta(E)|, \qquad \Omega_\Delta(E) \equiv \{x \in \mathcal{X}^N : E \le E(x) < E + \Delta\}. \tag{2.46}$$

在许多感兴趣的系统中，如果能量随 N 线性标度，能谱会在 $N \to \infty$ 时以指数方式发散。更准确地说，存在函数 $s(e)$，使得对于两个给定数 e 和 $\delta > 0$，

$$\lim_{N\to\infty} \frac{1}{N} \log \mathcal{N}_{N\delta}(Ne) = \sup_{e' \in [e, e+\delta]} s(e'). \tag{2.47}$$

函数 $s(e)$ 称为*微正则熵密度*。式 (2.47) 的陈述常被改写为更紧凑的形式：

$$\mathcal{N}_\Delta(E) \doteq_N \exp\left[N s\left(\frac{E}{N}\right)\right]. \tag{2.48}$$

全书用记号 $A_N \doteq_N B_N$ 表示两个通常随 N 指数变化的量，在大 N 时的首要指数阶相等，即 $\lim_{N\to\infty} N^{-1} \log(A_N/B_N) = 0$。当大变量 N 不会引起歧义时，我们常省略点等号下方的指标。

微正则熵密度 $s(e)$ 包含大量关于系统的信息。此外，它通过一个基本关系直接联系于强度型热力学势：

命题 2.6. *如果式 (2.47) 的微正则熵密度对任意 e 都存在，并且式 (2.47) 中的极限关于 e 一致，则自由熵密度存在并满足*

$$\phi(\beta) = \max_e [s(e) - \beta e]. \tag{2.49}$$

如果 $s(e) - \beta e$ 的最大值唯一，则内能密度等于 $\arg\max_e [s(e) - \beta e]$。

证明. 关于该陈述的严格证明，参见 Galavotti（1999）和 Ruelle（1999）。基本思想是将配分函数写为

$$Z_N(\beta) \doteq \sum_{k=-\infty}^{\infty} \mathcal{N}_\Delta(k\Delta) e^{-\beta\Delta} \doteq \int de\, \exp\{N s(e) - N\beta e\}, \tag{2.50}$$

并以鞍点法计算最后一个积分。 □

译注： 式 (2.50) 的第一项 Boltzmann 指数照原文印为 $e^{-\beta\Delta}$；按分箱能量 $k\Delta$ 的定义，需核查其中是否漏写 k。由式 (2.47) 的固定宏观区间极限直接转写为固定 Δ 的点态指数等价 (2.48) 也需要额外正则性，原文在此未列出。

例 2.7. *考虑 N 个相同的两能级系统：$\mathcal{X}^N = \mathcal{X} \times \cdots \times \mathcal{X}$，其中 $\mathcal{X} = \{1, 2\}$。取能量为单系统能量之和：$E(x) = E_{\text{single}}(x_1) + \cdots + E_{\text{single}}(x_N)$，其中 $x_i \in \mathcal{X}$。与上一节一样，设 $E_{\text{single}}(1) = \epsilon_1$、$E_{\text{single}}(2) = \epsilon_2 > \epsilon_1$，并记 $\Delta = \epsilon_2 - \epsilon_1$。*

该模型的能谱很简单。对任何能量 $E = N\epsilon_1 + n\Delta$，存在 $\binom{N}{n}$ 个满足 $E(x) = E$ 的构型 x。因此，根据定义 (2.47) 得到

$$s(e) = H\left(\frac{e-\epsilon_1}{\Delta}\right). \tag{2.51}$$

现在可利用式 (2.49) 得到

$$f(\beta) = \epsilon_1 - \frac{1}{\beta}\log(1+e^{-\beta\Delta}), \tag{2.52}$$

它与直接使用定义 (2.18) 得到的结果一致。[9]

物理学家对热力学极限的高度关注，由宏观物质中巨大数目的自由度充分解释。还应强调，热力学极限的意义比这些巨大数字所暗示的更加普遍。首先，相当小的系统常常已能由热力学极限很好地近似。这对物理系统的数值模拟极为重要：我们当然无法在计算机上模拟 10^{23} 个分子！即便热力学极限不是良好近似，分析对这一极限的偏离也常能产生有益结果。最后，分析 $N \to \infty$ 极限所获得的洞见，对于理解中等规模系统总是至关重要。

2.5 铁磁体与 Ising 模型

磁性材料包含具有磁矩的分子。磁矩是三维向量，趋向于与分子所感受到的磁场对齐。此外，两个不同分子的磁矩之间也相互作用。量子力学在磁性中起重要作用；由于量子效应，磁矩可能的构型空间变成离散的，这也是磁矩间所谓交换相互作用的来源。在许多材料中，交换相互作用使两个磁矩对齐时能量较低。虽然单个磁矩在外场中的行为在定性上比较简单，但当我们考虑一组相互作用的磁矩时，问题会丰富得多，并展现出显著的集体现象。

描述这类材料的一个简单数学模型是 Ising 模型。它用位于 d 维立方晶格某个区域顶点上的 Ising 自旋描述磁矩。为简单起见，考虑边长为 L 的立方区域 $\Lambda = \{1,\dots,L\}^d$。每个格点 $i \in \Lambda$ 上有一个 Ising 自旋 $\sigma_i \in \{+1,-1\}$。系统的一个构型 $\sigma = (\sigma_1 \dots \sigma_N)$ 由指定全部自旋的取值得到。因此构型空间 $\mathcal{X}^N = \{+1,-1\}^\Lambda$ 具有式 (2.1) 的形式，其中 $\mathcal{X} = \{+1,-1\}$、$N = L^d$。

铁磁 Ising 模型的定义还需给出能量函数。构型 σ 的能量为

$$E(\sigma) = -\sum_{(ij)}\sigma_i\sigma_j - B\sum_{i\in\Lambda}\sigma_i, \tag{2.53}$$

其中对 (ij) 的求和遍及 Λ 中所有互为最近邻的无序点对 i,j，实数 B 度量施加的外磁场。

确定该模型在热力学极限下的自由能密度 $f(\beta)$ 并非易事。模型由 Wilhem Lenz 在 20 世纪 20 年代初提出，他将分析这一模型的任务交给学生 Ernst Ising。Ising 在其 1924 年的博士论文中解决了 $d = 1$ 情形，并表明不存在相变。1948 年，Lars Onsager 出色地解决了 $d = 2$ 的情形，给出了第一个具有二级相变的可解 “有限维” 模型。在更高维中，虽然解的许多重要特征已得到很好理解，问题仍未解决。

开始任何计算之前，先讨论我们预期该模型具有怎样的定性性质。两个极端情形容易理解。在无穷高温 $\beta = 0$ 时，能量 (2.53) 不再起作用，Boltzmann 分布给所有构型相同的权重 2^{-N}，

[9] 译注：此处按原文记为 H；第 1 章的二元熵 H 使用以 2 为底的对数，而本节微正则熵的定义使用自然对数。若直接比较这两个定义，需乘以相应的换底因子。

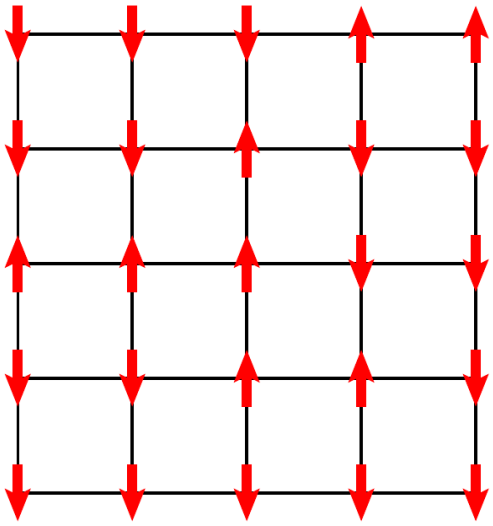


图 2.2: 二维 Ising 模型在 $L = 5$ 时的一个构型。每个顶点 i 有自旋 σ_i：$\sigma_i = +1$ 时箭头向上，$\sigma_i = -1$ 时向下。能量 (2.53) 有两类贡献：(i) 图中每条边 (ij) 对应一项 $-\sigma_i\sigma_j$，两个相邻自旋同向时该项能量最低；(ii) 每个格点 i 因与外磁场耦合而有一项 $-B\sigma_i$。图示构型的能量为 $-8 + 9B$。原图取自 Part A 草稿第 36 页。

因而我们得到一组完全独立的自旋。在零温 $\beta \to \infty$ 时，Boltzmann 分布集中于基态。若无磁场，$h = 0$，则有两个简并基态：自旋全向上的构型 $\sigma^{(+)}$，即 $\sigma_i = +1$；以及自旋全向下的构型 $\sigma^{(-)}$，即 $\sigma_i = -1$。如果将磁场设为非零值，则其中一个构型占主导：$h > 0$ 时为 $\sigma^{(+)}$，$h < 0$ 时为 $\sigma^{(-)}$。

注意系统对外磁场 h 的反应在这两种情形中非常不同。为看清这一点，定义“重新标度”的磁场 $x = \beta h$，并在保持 x 固定的情况下取 $\beta \to 0$ 或 $\beta \to \infty$ 极限。两种极限中，L 内任一自旋的期望值分别为

$$\langle \sigma_i \rangle = \begin{cases} \tanh(x), & \beta \to 0, \\ \tanh(Nx), & \beta \to \infty. \end{cases} \tag{2.54}$$

当 $\beta \to 0$ 时各自旋独立响应；相反，当 $\beta \to \infty$ 时它们作为整体响应，称为协同响应。[10]

描述系统对外磁场响应的一个有用量是平均磁化强度：

$$M_N(\beta, B) = \frac{1}{N} \sum_{i \in \mathsf{L}} \langle \sigma_i \rangle. \tag{2.55}$$

由于向上与向下方向的对称性，$M_N(\beta, B)$ 是 B 的奇函数，特别有 $M_N(\beta, 0) = 0$。协同响应可以通过考虑自发磁化强度来体现：

$$M_+(\beta) = \lim_{B \to 0^+} \lim_{N \to \infty} M_N(\beta, B). \tag{2.56}$$

[10]译注：本段场强在能量式 (2.53) 中记为 B，原文此处改用 h。保持 $x = \beta h$ 固定而令 $\beta \to 0$ 时，所取的是联合标度极限，而非固定外场的普通高温极限。

重要的是，非零自发磁化只能在无限系统中出现：式 (2.56) 的极限顺序至关重要。迄今的分析表明，自发磁化在 $\beta=\infty$ 时存在：$M_+(\infty)=1$；另一方面 $M_+(0)=0$。可以证明，自发磁化 $M(\beta)$ 在高温相 $\beta<\beta_c(d)$ 中总为零，这种相称为*顺磁相*。在一维（$d=1$）中，我们将在下文证明 $\beta_c(1)=\infty$。除零温 $\beta=\infty$ 外，自发磁化总为零；这称为零温相变。在 $d\geq 2$ 维中，$\beta_c(d)$ 有限，且在所谓的*铁磁相* $\beta>\beta_c$ 内 $M(\beta)$ 非零：$\beta=\beta_c$ 处发生相变。温度 $T_c=1/\beta_c$ 称为*临界温度*。下文将讨论 $d=1$ 情形和模型的一个变体——Curie–Weiss 模型，其中每个自旋都与其他所有自旋相互作用；这是一个在有限温度发生相变的可解模型。

2.5.1 一维情形

$d=1$ 情形的优点是容易求解。我们希望计算 N 个自旋、能量为 $E(\sigma)=-\sum_{i=1}^{N-1}\sigma_i\sigma_{i+1}-B\sum_{i=1}^{N}\sigma_i$ 的系统的配分函数 (2.4)。我们将使用称为*转移矩阵法*的方法，它属于计算机科学家熟悉的一般“动态规划”策略。

引入在固定 σ_{p+1} 时对所有自旋 $\sigma_1,\dots,\sigma_p$ 的构型求和得到的部分配分函数：

$$z_p(\beta,B,\sigma_{p+1})\equiv\sum_{\sigma_1,\dots,\sigma_p}\exp\left[\beta\sum_{i=1}^{p}\sigma_i\sigma_{i+1}+\beta B\sum_{i=1}^{p}\sigma_i\right]. \tag{2.57}$$

配分函数 (2.4) 由 $Z_N(\beta,B)=\sum_{\sigma_N}z_{N-1}(\beta,B,\sigma_N)\exp(\beta B\sigma_N)$ 给出。显然 z_p 满足递推关系

$$z_p(\beta,B,\sigma_{p+1})=\sum_{\sigma_p=\pm1}T(\sigma_{p+1},\sigma_p)z_{p-1}(\beta,B,\sigma_p), \tag{2.58}$$

其中所谓转移矩阵 $T(\sigma,\sigma')=\exp[\beta\sigma\sigma'+\beta B\sigma']$ 是一个 2×2 矩阵：

$$T=\begin{pmatrix}e^{\beta+\beta B} & e^{-\beta-\beta B}\\ e^{-\beta+\beta B} & e^{\beta-\beta B}\end{pmatrix}. \tag{2.59}$$

引入两个二分量向量 $\psi_L=(\exp(\beta B),\exp(-\beta B))^{T}$、$\psi_R=(1,1)^{T}$，以及这类向量的标准内积 $(a,b)=a_1b_1+a_2b_2$，配分函数可以写为矩阵形式：

$$Z_N(\beta,B)=(\psi_L,T^{N-1}\psi_R). \tag{2.60}$$

设 λ_1,λ_2 为 T 的本征值，ψ_1,ψ_2 为相应本征向量。由于 ψ_1,ψ_2 可选为线性无关，ψ_R 可以分解为 $\psi_R=u_1\psi_1+u_2\psi_2$，于是配分函数可表示为

$$Z_N(\beta,B)=u_1(\psi_L,\psi_1)\lambda_1^{N-1}+u_2(\psi_L,\psi_2)\lambda_2^{N-1}. \tag{2.61}$$

对矩阵 T 对角化得到

$$\lambda_{1,2}=e^{\beta}\cosh(\beta B)\pm\sqrt{e^{2\beta}\sinh^2(\beta B)+e^{-2\beta}}. \tag{2.62}$$

当 β 有限且取大 N 极限时，配分函数由最大本征值 λ_1 主导，自由熵密度由 $\phi=\log\lambda_1$ 给出：

$$\phi(\beta,B)=\log\left[e^{\beta}\cosh(\beta B)+\sqrt{e^{2\beta}\sinh^2(\beta B)+e^{-2\beta}}\right]. \tag{2.63}$$

使用同样的转移矩阵技术，可以计算可观测量的期望。例如某个自旋的期望值为

$$\langle \sigma_i \rangle = \frac{1}{Z_N(\beta, B)} (\psi_L, T^{i-1} \widehat{\sigma} T^{N-i} \psi_R), \tag{2.64}$$

其中 $\widehat{\sigma}$ 为矩阵

$$\widehat{\sigma} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}. \tag{2.65}$$

对位置 i 求平均，就可以计算平均磁化强度 $M_N(\beta, B)$。在热力学极限中得到

$$\lim_{N\to\infty} M_N(\beta, B) = \frac{\sinh(\beta B)}{\sqrt{\sinh^2(\beta h) + e^{-4\beta}}} = \frac{1}{\beta} \frac{\partial \phi}{\partial B}(\beta, B). \tag{2.66}$$

自由能和平均磁化强度对 $\beta < \infty$ 的 β, h 都是解析函数。特别地，自发磁化在任何非零温度都消失：

$$M_+(\beta) = 0, \qquad \forall \beta < \infty. \tag{2.67}$$

译注：式 (2.66) 的分子使用 B、分母使用 h；原文照此印出，需核查两者是否表示同一外场。

图 2.3 给出了平均磁化强度 $M(\beta, B) \equiv \lim_{N\to\infty} M_N(\beta, B)$ 在不同逆温度 β 下随外磁场 h 的变化。随着 β 增大，曲线越来越陡。通过计算平均磁化强度的磁化率，可以使这一说法更定量：

$$\chi_M(\beta) = \frac{\partial M}{\partial h}(\beta, 0) = \beta e^{2\beta}. \tag{2.68}$$

这一结果可以解释如下。处于外场中的单个自旋具有磁化率 $\chi(\beta) = \beta$。若考虑被约束为取相

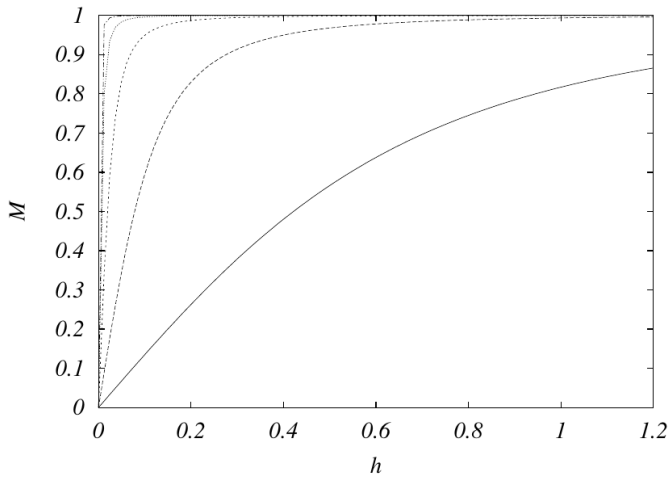


图 2.3: 一维 Ising 模型的平均磁化强度随磁场 B 的变化。逆温度分别为 $\beta = 0.5, 1, 1.5, 2$，曲线由下到上依次对应这些值。图取自 Part A 草稿第 40 页。

同值的 N 个自旋，相应磁化率将为 $N\beta$，如式 (2.54)。在当前情形中，系统的行为仿佛自旋被分组成每组 $\chi(\beta)/\beta$ 个自旋；每组内自旋被约束为相同取值，而不同组的自旋相互独立。

*计算关联函数可进一步支持这种定性解释。当 $h=0$ 且 $\delta N<i<j<(1-\delta)N$ 时，在大 N 下有

$$\langle\sigma_i\sigma_j\rangle = e^{-|i-j|/\xi(\beta)} + \Theta(e^{-\alpha N}), \tag{2.69}$$

其中 $\xi(\beta) = -1/\log\tanh\beta$。注意，$\xi(\beta)$ 给出系统内两个自旋强相关的典型距离，因此通常称为模型的*关联长度*。温度下降时，关联长度增大：自旋在更大的距离上保持相关。结果 (2.69) 与我们对磁化率的解释显然一致。特别地，当 $\beta\to\infty$ 时，$\xi(\beta)\approx e^{2\beta}/2$ 且 $\chi(\beta)\approx 2\beta\xi(\beta)$。

关联长度与磁化率之间的联系十分一般，可以理解为涨落耗散定理 (2.44) 的一个结果：

$$\begin{aligned}\chi_M(\beta) &= \beta N\left\langle\left(\frac{1}{N}\sum_{i=1}^N\sigma_i\right);\left(\frac{1}{N}\sum_{i=1}^N\sigma_i\right)\right\rangle\\ &= \frac{\beta}{N}\sum_{i,j=1}^N\langle\sigma_i;\sigma_j\rangle = \frac{\beta}{N}\sum_{i,j=1}^N\langle\sigma_i\sigma_j\rangle,\end{aligned} \tag{2.70}$$

其中最后一个等式来自 $B=0$ 时 $\langle\sigma_i\rangle=0$。利用式 (2.69) 得到

$$\chi_M(\beta) = \beta\sum_{i=-\infty}^{+\infty} e^{-|i|/\xi(\beta)} + \Theta(e^{-\alpha N}). \tag{2.71}$$

因此，较大的磁化率显然必然对应较大的关联长度。

2.5.2 Curie–Weiss 模型

一维模型的精确解使 Ising 认为任何维数中都不可能存在相变。此前约三十年，Pierre Curie 曾提出铁磁性的定性理论。该理论假设在非零温度 T_c（即所谓 “Curie 点”）存在相变，且 $T<T_c$ 时有非零自发磁化。这个难题最终由 Onsager 的二维模型解解决。

Curie 理论在一个相当抽象的模型——所谓 Curie–Weiss 模型——中得到精确实现。我们将在此介绍它，作为存在有限温度相变的最简单可解模型之一。我们仍有 N 个 Ising 自旋 $\sigma_i\in\{\pm1\}$，其构型由 $\sigma=(\sigma_1,\dots,\sigma_N)$ 给出。但自旋不再位于 d 维晶格上，而是全部两两相互作用。在磁场 B 中，能量函数为

$$E(\sigma) = -\frac{1}{N}\sum_{(ij)}\sigma_i\sigma_j - B\sum_{i=1}^N\sigma_i, \tag{2.72}$$

其中对 (ij) 的求和遍及所有自旋对。注意交换项前特别的 $1/N$ 标度。下面给出的精确解说明，这是在热力学极限中得到非平凡自由能密度的唯一选择。这个结论容易直观理解：对 (ij) 的求和有 $O(N^2)$ 个 $O(1)$ 的项，为使能量按 N 标度，需要在前面放置系数 $1/N$。

采用能量函数 (2.72)，我们放弃了对任何有限维几何结构的描述。这是一个强烈简化，但优点是模型可以精确求解。Curie–Weiss 模型是一个大家族的第一个例子，这个家族即所谓的*平均场模型*；全书将探索这个家族的许多实例。

计算配分函数的一种途径是注意到能量函数可以用一个简单的可观测量——*瞬时磁化强度*——表示：

$$m(\sigma) = \frac{1}{N}\sum_{i=1}^N\sigma_i. \tag{2.73}$$

注意，它是构型 σ 的函数，不应与它的期望值——平均磁化强度，见式 (2.55)——混淆。它是“简单”可观测量，因为它等于依赖单个自旋的可观测量之和。

我们可以用构型的瞬时磁化强度写出其能量：

$$E(\sigma) = \frac{1}{2}N - \frac{1}{2}Nm(\sigma)^2 - NBm(\sigma). \tag{2.74}$$

这蕴含配分函数公式

$$Z_N(\beta, B) = e^{-N\beta/2} \sum_m \mathcal{N}_N(m) \exp\left\{ \frac{N\beta}{2} m^2 + N\beta B m \right\}, \tag{2.75}$$

其中对 m 的求和遍及 N 个 Ising 自旋所有可能的瞬时磁化强度：$m = -1 + 2k/N$，k 是满足 $0 \le k \le N$ 的整数；$\mathcal{N}_N(m)$ 是具有给定瞬时磁化强度的构型数。它由二项式系数给出，其大 N 行为可用 Bernoulli 过程的熵函数表示：

$$\mathcal{N}_N(m) = \binom{N}{N\frac{1+m}{2}} \doteq \exp\left[N H\left(\frac{1+m}{2} \right) \right]. \tag{2.76}$$

译注：式 (2.74)–(2.76) 照原文保留。若式 (2.72) 的 (ij) 指不含自相互作用的无序自旋对，则直接计算得常数项为 $1/2$，而非 $N/2$；若取其他求和约定，也需核查相应归一化。原文配分函数前因子以及随后自由熵中的常数项因此需要结合约定复核。另外，第 1 章 H 的对数以 2 为底，而式 (2.76) 的自然指数对应自然对数熵，需要换底。

于是，在 N 的首要指数阶，配分函数可写为

$$Z_N(\beta, B) \doteq \int_{-1}^{+1} dm\, e^{N\phi_{\mathrm{mf}}(m;\beta,B)}, \tag{2.77}$$

其中定义

$$\phi_{\mathrm{mf}}(m; \beta, B) = -\frac{\beta}{2}(1 - m^2) + \beta B m + H\left(\frac{1+m}{2} \right). \tag{2.78}$$

式 (2.77) 中的积分容易用 Laplace 方法计算，得到自由能密度的最终结果：

$$\phi(\beta, B) = \max_{m \in [-1,+1]} \phi_{\mathrm{mf}}(m; \beta, B). \tag{2.79}$$

可以看出最大值在远离边界的点处取得，因此相应的 m 必须是 $\phi_{\mathrm{mf}}(m;\beta,B)$ 的驻点，满足鞍点方程 $\partial\phi_{\mathrm{mf}}(m;\beta,B)/\partial m = 0$：

$$m_* = \tanh(\beta m_* + \beta B). \tag{2.80}$$

译注：图 2.4 原图注对两个不同情形均写 $\beta < \beta_c$；按图及紧接着的正文，双最大值应对应 $\beta > \beta_c$，图注在此如实保留并提示这一不一致。

在上述推导中，我们在两个步骤上略显粗疏：用渐近形式替换二项式系数，以及将对 m 的求和变成积分。*请具有数学兴趣的读者证明这些步骤确实正确。

*稍作更多工作，上述方法可以推广到可观测量的期望值。例如考虑平均磁化强度 $M(\beta, B)$。容易证明，只要 $\phi_{\mathrm{mf}}(m;\beta,B)$ 关于 m 的最大值非简并，就有

$$M(\beta, B) \equiv \lim_{N\to\infty} \langle m(\sigma) \rangle = m_*(\beta, B) \equiv \arg\max_m \phi_{\mathrm{mf}}(m; \beta, B). \tag{2.81}$$

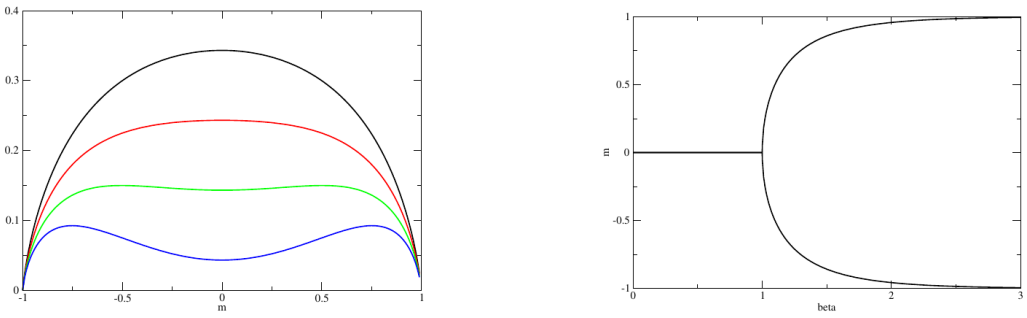


图 2.4: 左：$\phi_{\mathrm{mf}}(m;\beta,B=0)$ 随 m 的变化，$\beta=.7,.9,1.1,1.3$ 对应曲线从上到下。原图注称 $\beta<\beta_c=1$ 时 $m=0$ 是唯一最大值，又称 $\beta<\beta_c=1$ 时有两个对称值 $\pm m_+(\beta)$ 处的简并最大值。右：使 $\phi_{\mathrm{mf}}(m;\beta,B=0)$ 最大的 m 随 β 的变化；$\beta_c=1$ 处的相变由分岔标示。图取自 Part A 草稿第 43 页。

现在可以考察式 (2.79) 和 (2.80) 的含义。先考虑 $B=0$（见图 2.4）。函数 $\phi_{\mathrm{mf}}(m;\beta,0)$ 关于 m 对称。当 $0\le\beta\le 1\equiv\beta_c$ 时，它也是凹函数，并在 $m_*(\beta)=0$ 处取得唯一最大值。当 $\beta>1$ 时，$m=0$ 仍是驻点，但成为局部极小值，函数出现两个简并全局最大值 $m_\pm(\beta)$，满足 $m_+(\beta)=-m_-(\beta)>0$。这两个最大值在 $\beta=\beta_c$ 处从 $m=0$ 连续分岔出来。

在 β_c 处发生相变。计算自旋期望可以理解其含义。注意能量函数 (2.72) 在自旋翻转变换下对称：对所有 i，将 $\sigma_i\mapsto-\sigma_i$。因此 $\langle\sigma_i\rangle=\langle-\sigma_i\rangle=0$，平均磁化强度 $M(\beta,0)=0$。另一方面，式 (2.56) 定义的自发磁化强度在顺磁相 $\beta<\beta_c$ 时为零，在铁磁相 $\beta>\beta_c$ 时等于 $m_+(\beta)$。该相的物理解释如下：对于任何有限 N，瞬时磁化强度 $m(\sigma)$ 的概率密度具有位于 $m_\pm(\beta)$ 的两个对称峰，而且随着 N 增大这些峰越来越尖锐。任何破坏两峰之间对称性的外扰动，例如一个小的正磁场 B，都会使其中一个峰相对另一个峰更受偏好，因而系统产生自发磁化。注意，从数学角度说，相变是热力学极限 $N\to\infty$ 中系统的一种性质。

在物理磁体中，对称性破缺例如可能来自杂质、偶极相互作用与磁体形状共同产生的微妙效应，或者外磁场。结果是，当温度足够低时，一些系统——铁磁体——会产生自发磁化。如果加热由铁制成的磁体，其磁化强度将在临界温度 $T_c=1/\beta_c=770$ 摄氏度处消失。Curie–Weiss 模型是展示这种相变的一个简单可解例子。

习题 2.5. 计算 β 接近 β_c 时 $m_+(\beta)$ 与 $\phi(\beta,B=0)$ 的展开，并证明该相变是二级的。计算自发磁化强度在低温下的行为。

习题 2.6 (非均匀 Ising 链)**.** 只要相互作用是短程且平移不变的，一维 *Ising* 问题就不存在有限温度相变。但当 *Ising* 链中的耦合随距离增大而足够快地增长时，就可能发生相变。从物理角度看，这不是一个非常真实的模型，但作为相变的可解例子很有用。

考虑一条 *Ising* 自旋链 $\sigma_0,\sigma_1,\dots,\sigma_N$，能量为 $E(\sigma)=-\sum_{n=0}^{N-1}J_n\sigma_n\sigma_{n+1}$。假设耦合常数 J_n 构成正的单调递增序列，并以对数方式增长，更准确地说，$\lim_{n\to\infty}J_n/\log n=1$。当自旋 σ_N 固定为 $+1$（分别为 -1）时，用 $\langle\cdot\rangle_+$（分别为 $\langle\cdot\rangle_-$）表示对 *Boltzmann* 概率分布的期望。

1. 证明对任意 $n \in \{0, \dots, N-1\}$，磁化强度为

$$\langle \sigma_n \rangle_{\pm} = \prod_{p=n}^{N-1} \tanh(\beta J_p).$$

2. 证明临界逆温度 $\beta_c = 1/2$ 分隔了两种区域：若 $\beta < \beta_c$，则

$$\lim_{N\to\infty} \langle \sigma_n \rangle_{+} = \lim_{N\to\infty} \langle \sigma_n \rangle_{-} = 0;$$

若 $\beta > \beta_c$，则 $\lim_{N\to\infty} \langle \sigma_n \rangle_{\pm} = \pm M(\beta)$，且 $M(\beta) > 0$。

注意，此处对称性破缺场的作用由边界条件的选择承担。

译注： 习题 2.6 第 1 小问按原文对 + 和 − 两种边界都写出同一个正乘积；当边界自旋为 -1 时，需核查右侧是否遗漏负号。此外，对一般非均匀耦合，极限乘积还可能依赖固定位置 n；本题的极限记号保留原文，未作无依据修正。

2.6 Ising 自旋玻璃

在真实磁性材料中，局域磁矩受到多种来源的相互作用。除了上一节提到的交换相互作用外，它们还可能通过中间的传导电子等发生相互作用。因此，取决于所考虑的材料，其相互作用既可能是铁磁性的（平行时能量最低），也可能是反铁磁性的（方向相反时能量最低）。自旋玻璃是一族磁性质特别复杂的材料。它们可以通过将少量诸如锰的“过渡磁性金属”按 1 : 100 的比例稀释到诸如铜的“贵金属”中制得。在这种合金中，磁矩局域在锰原子处，而锰原子随机分布在铜背景中。取决于两个锰原子之间的距离，其磁矩间的净相互作用可能是铁磁性的，也可能是反铁磁性的。

对这些物理系统，一种广为接受的数学抽象是 Edwards–Anderson 模型。基本自由度仍然是 Ising 自旋 $\sigma_i \in \{-1, +1\}$，它们位于 d 维立方晶格 $\mathsf{L} = \{1, \dots, L\}^d$ 的顶点，$i \in \mathsf{L}$。因此构型空间为 $\{-1, +1\}^{\mathsf{L}}$。与 Ising 模型一样，能量函数写作

$$E(\sigma) = -\sum_{(ij)} J_{ij}\sigma_i\sigma_j - B\sum_{i\in\mathsf{L}} \sigma_i, \tag{2.82}$$

其中 $\sum_{(ij)}$ 遍及晶格的每一条边。与 Ising 铁磁体不同，此时每条边 (ij) 有一个不同的耦合常数 J_{ij}，其符号可以为正也可以为负。当 $J_{ij} > 0$ 时，自旋 σ_i, σ_j 之间的相互作用是铁磁性的；当 $J_{ij} < 0$ 时是反铁磁性的。图 2.5 给出了这一能量函数的图形表示。Boltzmann 分布为

$$p_\beta(\sigma) = \frac{1}{Z(\beta)} \exp\left\{ \beta \sum_{(ij)} J_{ij}\sigma_i\sigma_j + \beta B \sum_{i\in\mathsf{L}} \sigma_i \right\}, \tag{2.83}$$

$$Z(\beta) = \sum_{\sigma} \exp\left\{ \beta \sum_{(ij)} J_{ij}\sigma_i\sigma_j + \beta B \sum_{i\in\mathsf{L}} \sigma_i \right\}. \tag{2.84}$$

需要注意，耦合常数 $\{J_{ij}\}$ 与自旋 $\{\sigma_i\}$ 的作用完全不同。耦合常数只是定义能量函数的参数，与磁场 B 类似；计算配分函数时并不对它们求和。原则上，对于磁性材料的每一个具体样品，

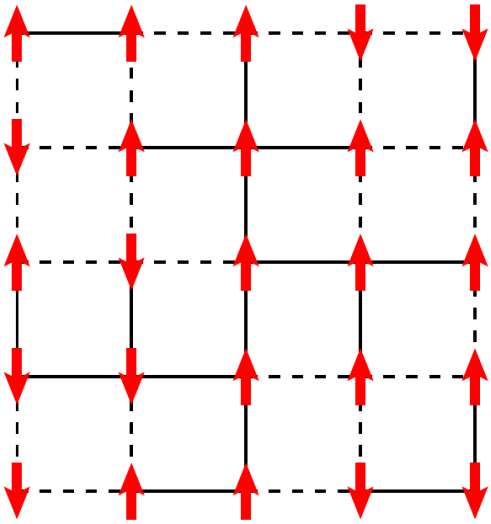


图 2.5: $L = 5$ 时二维 Edwards–Anderson 模型的一个构型。自旋由两类相互作用耦合：铁磁相互作用（$J_{ij} = +1$）用实线表示，反铁磁相互作用（$J_{ij} = -1$）用虚线表示。图示构型的能量为 $-14 - 7h$。图取自 Part A 草稿第 45 页。

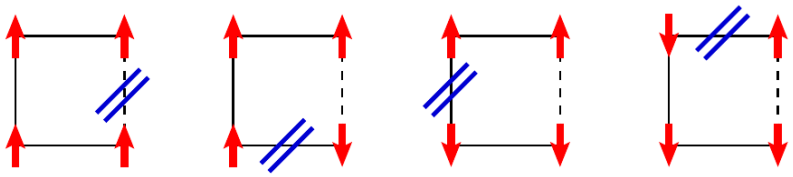


图 2.6: 一个小型 Edwards–Anderson 模型的四个构型：实线表示铁磁相互作用（$J_{ij} = +1$），虚线表示反铁磁相互作用（$J_{ij} = -1$）。零磁场（$h = 0$）下，四个构型简并，能量均为 $E = -2$。短划线标示未得到满足的相互作用。注意不存在能量更低的构型。该系统受到阻挫，因为不可能同时满足所有约束。图取自 Part A 草稿第 46 页。

都应通过实验估计 J_{ij} 的值，然后计算配分函数。我们本可以使用 $Z(\beta, B; \{J_{ij}\})$、$p_{\beta,B;\{J_{ij}\}}(\sigma)$ 等记号，显式写出配分函数与 Boltzmann 分布对耦合常数的依赖；但在不必要时，我们更愿意采用简洁记号。

目前对 Edwards–Anderson 模型的理解远不如上一节介绍的铁磁模型。造成这种差异的基本原因是阻挫，图 2.6 以 $L = 2$、$d = 2$ 的模型（即仅由 4 个自旋构成的模型）作了说明。只要存在彼此冲突的局部约束，即不可能同时满足所有约束，自旋玻璃就受到阻挫。在 Edwards–Anderson 模型中，一个基本方格由构成一个正方形的四个相邻自旋组成。当且仅当沿该基本方格四条边的 J_{ij} 的乘积为负时，该方格受到阻挫。正如图 2.6 所示，此时不可能同时使与每条边相关的四个局部能量项达到最小。

在自旋玻璃中，受到阻挫的基本方格以有限密度存在会产生极为复杂的能量景观。所有相互作用造成的整体效果并不是简单地将各自的效果 “相加”，而是复杂相互影响的结果。基态自旋构型，即满足尽可能多相互作用的构型，很难找到，也不能根据对称性猜出。在自旋玻璃中，也常常会发现与基态截然不同、但能量十分接近基态能量的构型。我们将在全书中探索这些及相关问题。[11]

注释

有许多优秀教材介绍统计物理和热力学，例如 Reif（1965）或 Huang（1987）的著作。进一步的高级教材可以参阅 Ma（1985） 和 Parisi（1998b）。更注重数学的介绍可见 Gallavotti（1999） 和 Ruelle（1999） 的著作。

零外场下的二维 Ising 模型也可以通过转移矩阵技术求解，例如参见 Baxter（1982）。从晶格的一列转移到下一列的转移矩阵是一个 $2^L \times 2^L$ 矩阵，其维数随晶格尺寸 L 以指数方式发散，因此求其最大本征值是一项复杂任务。到目前为止，还没有人找到 $B \neq 0$ 情形的解。

自旋玻璃将是贯穿本书的反复主题，后续章节还会作更多讨论。从物理学家观点对该主题的介绍，可见 Fischer 和 Hertz（1993） 的著作或 Binder 和 Young（1986） 的综述。阻挫概念由 Gerard Toulouse（1977） 在一篇精彩的论文中引入。

[11] 译注：原文将基态解释为满足相互作用数目最多的构型；若耦合强度大小不等，能量还依赖未满足相互作用的权重，这种计数描述需要条件。

第三章　组合优化导论

本章对理论计算机科学中的若干基本概念作初步介绍。计算机能够或不能高效完成哪些计算任务？解决某个具体问题需要多少资源（时间、内存等）？某个具体求解方法——算法——的性能如何，当存在多个方法时又应优先选择哪一个？有些问题是否在本质上比其他问题更困难？这些都是人们希望回答的问题。

计算问题的一个大家族由组合优化问题构成：从一个有限集合中寻找使易于计算的目标函数最大化或最小化的成员。这些问题具有若干特别有趣的特点。首先，大多数时候，它们可以转化为判定问题，即要求回答“是 / 否”的问题；判定问题是能够形成丰富计算复杂性理论的最简单问题。其次，优化问题在应用与纯科学中无处不在，尤其与统计力学和编码理论都有明显联系。最后，这个家族规模庞大且已得到充分研究，因此是理解一些高级问题的理想背景。但应记住，计算并不只有组合优化。另一个不同且在某种意义上更大的家族由计数问题构成：要求统计有限集合中有多少元素具有某个容易检验的性质。后续章节将讨论一些此类问题。还有一个大家族是连续优化问题，本书基本不予讨论。

本章组织如下。第 3.1 节通过一个简单例子引入组合优化的研究，并给出全书使用的图论基本定义。第 3.2 节给出一般定义及术语，第 3.3 节用更多例子进一步说明。第 3.4 节非形式地介绍计算复杂性的一些基本概念。正如前面提到的，组合优化问题常见于纯科学和应用，第 3.5、3.6 节将简要讨论统计物理和编码的例子。

3.1　第一个例子：最小生成树

最小生成树问题容易表述，也可能出现在许多实际应用中。例如，假设一栋建筑内有一组计算机，你可能希望将它们两两连接，使所得网络完全连通，同时使用最少的电缆。

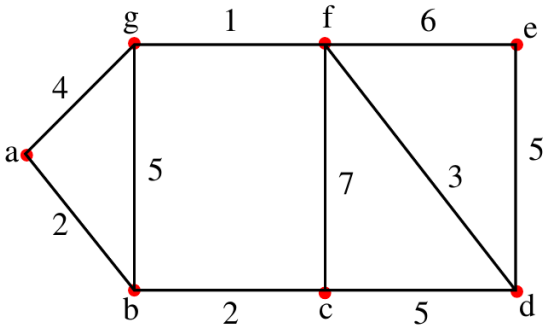


图 3.1: 此图有 7 个顶点（标记为 a 至 g）和 10 条边，每条边的“代价”标在其旁。最小生成树问题要求寻找一个连接全部顶点、没有回路且代价最小的子图。图取自 Part A 草稿第 49 页。

3.1.1 问题定义与图论基础

对上述实际问题进行数学抽象，首先需要给出图论的基本定义。一个图由顶点集合 $\mathcal{V}$ 与连接它们的边集合 $\mathcal{E}$ 组成，记为 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$，顶点以 $\{1, 2, \ldots, |\mathcal{V}|\}$ 标记。顶点集合可以是任意有限集合，但常常取前 $|\mathcal{V}|$ 个整数：$\mathcal{V} = \{1, 2, \ldots, |\mathcal{V}|\}$。边就是不同顶点的无序对，$\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$。例如，连接顶点 i, j 的边记为 $e = (i, j)$。*加权图*是对每条边赋予一个代价（实数）的图。顶点的*度*是与该顶点相连的边数。两个顶点 i, j 之间的一条*路径*是边的集合 $\{(j, i_2), (i_2, i_3), (i_3, i_4), \ldots, (i_{r-1}, i_r), (i_r, j)\}$。[1]如果对任意一对顶点都存在连接二者的路径，则称该图*连通*。*完全连通图*或*完全图*又称*团*，其中所有 $|\mathcal{V}|(|\mathcal{V}| - 1)/2$ 条边均存在。*圈*是起点和终点为同一顶点的路径。*树*是没有圈的连通图。

考虑图 3.1。现在要求你寻找一棵树：由部分边构成的无圈子图，使得任意两个顶点都恰好由一条路径连接；此时称该树为*生成树*。寻找这样的子图是一项简单任务。例如，边集合 $\{(a, b), (b, c), (c, d), (b, g), (d, e)\}$ 就完成了任务。然而，在我们的问题中，每条边都被赋予代价。假设一个子图的代价等于其各边代价之和，那么你的问题就是寻找代价最小的生成树。这是一个非平凡问题。[2]

一般而言，一个最小生成树（MST）问题的实例由一幅连通加权图给出，其中每条边 e 的代价为 $w(e) \in \mathbb{R}$。优化问题是寻找代价最小的生成树。我们希望找到一个算法：给定 MST 问题的实例后输出代价最低的生成树。

3.1.2 最小生成树的一个高效算法

简单直接的方法是枚举给定图的所有生成树并比较其权重。然而，生成树数目随图的规模增长非常快。以 N 个顶点上的完全图为例，根据 Cayley 公式，这样的图有 N^{N-2} 棵生成树。即便每棵树的代价都能在 10^{-3} 秒内计算完，寻找 $N = 12$ 的图的 MST 也需要两年，$N = 13$ 时需要半个世纪。另一个极端是图非常简单，可能只含少量生成树；极端情况下，图本身是一棵树，只有一棵生成树。尽管如此，在大多数有趣的例子中，情形几乎与完全图一样严峻。

下列定理可以给出好得多的算法：

定理 3.1. *设 $\mathcal{U} \subset \mathcal{V}$ 是顶点集合 $\mathcal{V}$ 的真子集，且 $\mathcal{U}$ 与 $\mathcal{V} \setminus \mathcal{U}$ 均非空。考虑连接 $\mathcal{U}$ 中顶点与 $\mathcal{V} \setminus \mathcal{U}$ 中顶点的边集合 $\mathcal{F}$，设 $e \in \mathcal{F}$ 是该集合中代价最低的一条边，即对任意 $e' \in \mathcal{F}$ 有 $w(e) \le w(e')$。若有多条这样的边，可任取其中一条。则存在一棵包含 e 的最小生成树。*

证明. 考虑一棵 MST T，假设它不含边 e。这条边形如 $e = (i, j)$，其中 $i \in \mathcal{U}$、$j \in \mathcal{V} \setminus \mathcal{U}$。生成树 T 必然包含一条从 i 到 j 的路径；该路径至少含有一条连接 $\mathcal{U}$ 与 $\mathcal{V} \setminus \mathcal{U}$ 的边 f，且 $f \neq e$。现在从 T 中删除 f 并加入 e，构造子图 T'。留给读者证明 T' 是生成树。

此外，$E(T') = E(T) + w(e) - w(f)$。由于 T 是 MST，有 $E(T') \ge E(T)$；另一方面，e 是 $\mathcal{F}$ 中代价最小的边，故 $w(e) \le w(f)$。因此 $w(e) = w(f)$，且 T' 是一棵包含 e 的 MST。 □

这一结果使我们能够逐步构造图的最小生成树。从单个顶点开始，每一步都可以向树中加入一条新边：在所有连接已有树与其余顶点的边中，选取代价最低者。经过 $N - 1$ 次迭代后，所得树将成为生成树。

[1]译注：路径描述按原文保留；作为从 i 到 j 的路径，首条边中的 j 可能应为 i，需结合上下文核查。

[2]译注：原例中的边集合如实照录，但图 3.1 有 7 个顶点，而列出的 5 条边不连接顶点 f，不能生成全部顶点。

MST 算法（Prim，1957）。 **输入：** 非空连通图 $\mathcal{G}=(\mathcal{V},\mathcal{E})$ 和权重函数 $w:\mathcal{E}\to\mathbb{R}_+$。 **输出：** 一棵最小生成树 T 及其代价 $E(T)$。

1. 令 $\mathcal{U}:=\{1\}$、$T:=\varnothing$、$E=0$。
2. 当 $\mathcal{V}\setminus\mathcal{U}$ 非空时：
   (a) 令 $\mathcal{F}:=\{e=(ij)\in\mathcal{E}:i\in\mathcal{U},\ j\in\mathcal{V}\setminus\mathcal{U}\}$。
   (b) 找到 $e_*:=\arg\min_{e\in\mathcal{F}}\{w(e)\}$，记 $e_*=(i_*,j_*)$，其中 $i_*\in\mathcal{U}$、$j_*\in\mathcal{V}\setminus\mathcal{U}$。
   (c) 令 $\mathcal{U}:=\mathcal{U}\cup i_*$、$T:=T\cup e_*$，并令 $E:=E+w(e_*)$。
3. 输出生成树 T 及其代价 E。

译注： 算法第 2(c) 步按原文写 $\mathcal{U}:=\mathcal{U}\cup i_*$，但上一步规定 $i_*\in\mathcal{U}$，因此该更新不会扩充 $\mathcal{U}$，不能按预期终止。结合前后的算法说明，需核查是否应加入外侧顶点 j_*；这里保留原算法而不静默修改。图 3.2 给出了图 3.1 所示问题的 MST。⋆应用上述算法容易得到它。[3]

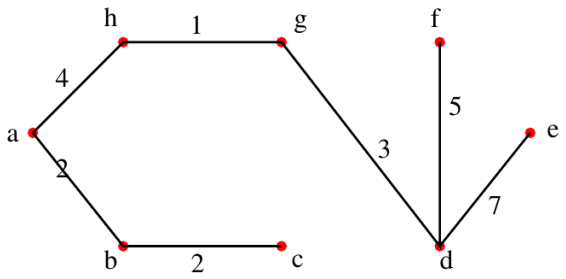


图 3.2: 原图注称：图 3.1 所定义图的一个最小生成树，其代价为 $E=17$。图取自 Part A 草稿第 51 页。

习题 3.1. *显式证明 MST 算法总是输出一棵最小生成树。*

定理 3.1 说明：对任意 $\mathcal{U}\subset\mathcal{V}$，连接 $\mathcal{U}$ 与 $\mathcal{V}\setminus\mathcal{U}$ 的边中任意一条代价最低边 e，都存在一棵包含 e 的 MST。这并不保证：当考虑两个不同的集合 $\mathcal{U}_1,\mathcal{U}_2$ 及各自的最低代价边 e_1,e_2 时，存在一棵同时包含 e_1,e_2 的 MST。上述算法通过构造这样的 $\mathcal{U}$ 序列并向树中加入相应最低权重边来运行，因此事先并不显然它会输出一棵 MST，除非 MST 是唯一的。

分析该算法在一个 N 节点图上构造生成树所需的基本操作数。这里“基本操作”指比较、加法、乘法等，每次都计一次。操作数当然取决于图，但考虑完全连通图可以得到简单上界。上述算法的大部分操作是在步骤 2(b) 中寻找 e_* 时比较边权。为确定 e_*，至多扫描连接 $\mathcal{U}$ 与 $\mathcal{V}\setminus\mathcal{U}$ 的 $|\mathcal{U}|\,|\mathcal{V}\setminus\mathcal{U}|=|\mathcal{U}|(N-|\mathcal{U}|)$ 条边。因为开始时 $|\mathcal{U}|=1$，且循环 2(a)–2(c) 的每次迭代都使其增加一个元素，所以比较次数以上界 $\sum_{U=0}^{N}U(N-U)\le N^3/6$ 为界。[4]这是一个多项式算法的例子，其计算时间按顶点数的幂律增长。定理所提供的洞见给出一种远优于朴素方法的算法，至少当 N 越来越大时如此。

[3]译注：此处的图与前图不一致：它出现了前图没有的顶点 h，并且所绘结构与原图顶点及边的对应关系不清；不能仅凭原图注认定它是前图的最小生成树。两图均按草稿保留。

[4]只需对已遇到的边维持一个有序列表，就可以容易地改进该算法。

3.2 一般定义

MST 是一个组合优化问题的例子。此类问题由可能实例的集合定义；MST 的一个实例由一幅连通加权图定义。一般地，组合优化问题的一个实例由允许构型的有限集合 $\mathcal{X}$ 和定义在该集合上、取值于 $\mathbb{R}$ 的代价函数 E 描述。优化问题是寻找最优构型 $C \in \mathcal{X}$，即代价 $E(C)$ 最小的构型。任何这类实例的集合都定义一个组合优化问题。对某个特定 MST 实例，构型空间就是给定图上所有生成树的集合，而与每棵生成树关联的代价函数等于其各边代价之和。

如果一个算法对优化问题的每个实例都给出最优构型，或者计算出其代价，我们就说该算法解决了这个优化问题。在我们将讨论的所有问题中，都有一种“自然”的问题规模度量 N，通常是定义构型所用变量的数目，例如 MST 中图的边数。构型数在大 N 时按 c^N 标度，或在某些情形中甚至更快，例如 $N!$ 或 N^N。注意，相当一般地说，计算某个具体构型的代价函数是容易的。因此，求解组合优化问题的困难本质上来自构型空间的规模。

估计算法复杂性的一个普遍接受的做法，是统计求解问题所需的“基本操作”数目。通常关注该量在 $N \to \infty$ 时的渐近行为。构造复杂性尽可能低的算法，显然具有重大实际意义。

组合优化问题可以在几个不同精细程度上求解。通常区分三类问题：

- 优化问题：寻找一个最优构型 C^*。
- 求值问题：确定最优构型的代价 $E(C^*)$。
- 判定问题：回答“是否存在代价小于给定值 E_0 的构型?”

3.3 更多例子

上一节描述的一般框架涵盖许多在实践和理论上都有意义的问题。下面列出若干例子。

3.3.1 欧拉回路

最早有文献记载的例子之一可追溯至 18 世纪。柯尼斯堡旧城有七座桥（见图 3.3），居民想知道能否恰好经过每座桥一次并回到家。这可以推广并用图论语言表述为判定问题。*多重图*与图的定义相同，只是两个给定顶点之间可以有多条边。问题是判断是否存在一条回路，恰好经过图中每条边一次并返回起点。这种回路现在称为*欧拉回路*：欧拉于 1736 年解决了这一问题，证明了下列定理。与普通图一样，顶点的度定义为以该顶点为端点的边数。

定理 3.2. *给定连通多重图，存在欧拉回路当且仅当每个顶点的度均为偶数。*

该定理直接给出一个复杂度随顶点数线性增长的判定算法：遍历所有顶点，检查其度。

习题 3.2. 证明：*如果存在欧拉回路，则各顶点的度必为偶数。*

证明逆命题稍困难。一种可能的途径是证明下面稍强的结果：如果连通图 $\mathcal{G}$ 中除 i, j 外所有顶点的度均为偶数，则存在从 i 到 j 的路径，恰好经过 $\mathcal{G}$ 中每条边一次。可以对顶点数作归纳证明。[提示：从 i 出发，沿边 (i, i') 走一步。证明可以选取 i'，使剩余图 $\mathcal{G} \setminus (i, i')$ 连通。]

译注：以上习题及提示按原文保留；若 i, j 的度未明确限定为奇数，所述结论并不总成立，删除边后含孤立顶点的剩余图也未必连通。定理的算法复杂度亦依赖输入表示与度数是否已知。

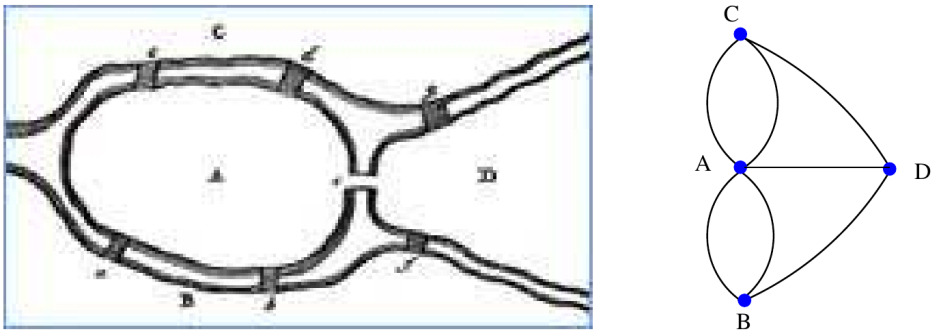


图 3.3: 左：欧拉 1736 年论文中所绘柯尼斯堡旧城七桥图。问题是能否在城中行走，恰好经过每座桥一次并回到家。右：概括该问题的图；顶点 A, B, C, D 表示河流分隔的陆地，不同陆地之间有桥时相应顶点之间有边。问题是在图上寻找恰好经过每条边一次的闭回路。取自 Part A 草稿第 53 页。

3.3.2 Hamilton 圈

欧拉定理一个多世纪之后，科学家 William Hamilton 爵士于 1859 年提出一种称为 icosian game（Hamilton 游戏）的游戏。其推广形式实质上询问图中是否存在 Hamilton 圈，即恰好经过每个顶点一次并返回起点的路径。这也是一个判定问题，乍看与欧拉回路很相似，但实际上复杂得多。现有判断给定图是否存在 Hamilton 圈的最佳算法，其运行时间随顶点数 N 指数增长。此外，本章稍后介绍的计算复杂性理论强烈暗示该问题本质上困难。

3.3.3 旅行商问题

给定一个有 N 个点的完全图及各对点 $1 \le i < j \le N$ 之间的距离 d_{ij}，著名的旅行商问题（TSP）是寻找总长度最短的 Hamilton 圈。可以考虑平面一部分中的点以及欧氏距离（此时称为欧氏 TSP），但当然也可以更一般地表述此问题，使 d_{ij} 代表一般代价，它们不一定是距离。与 Hamilton 圈问题一样，迄今已知的最佳 TSP 算法在大 N 时运行时间随 N 指数增长。尽管如此，含数千个点的欧氏问题仍可求解。

3.3.4 分配问题

给定 N 个人、N 项工作，以及给出第 i 个人对第 j 项工作的适合程度的矩阵 C_{ij}，分配问题是寻找工作与人员之间恰好一一对应的分配，使适合程度之和最大。一个构型由 N 个指标的一个排列 π 描述（因此有 $N!$ 个构型），其代价为 $\sum_i C_{i\pi(i)}$。这是多项式问题的例子：存在运行时间按 N^3 增长的求解算法。

3.3.5 可满足性

可满足性问题要求寻找 N 个布尔变量 $x_i \in \{\mathrm{T}, \mathrm{F}\}$ 的取值，使一组逻辑约束成立。由于每个变量可以为真或假，构型空间大小为 $|\mathcal{X}| = 2^N$。每个逻辑约束在此称为子句，有特殊形式：它是若干变量或其否定的逻辑或（以符号 $\vee$ 表示）。例如 $x_1 \vee \overline{x}_2$ 是一个 2-子句（即长度为 2、恰涉及两个变量的子句），当 $x_1 = \mathrm{T}$ 或 $x_2 = \mathrm{F}$ 或二者同时成立时满足。$\overline{x}_1 \vee \overline{x}_2 \vee x_3$ 是一个

3-子句，除 $x_1 = x_2 = \mathrm{T}$、$x_3 = \mathrm{F}$ 外，三个变量的所有构型都满足它。问题是确定是否存在满足全部约束的构型（判定问题），或寻找违反约束数最少的构型（优化问题）。当所有子句长度不大于 2 时，判定问题容易：存在运行时间随 N 线性增长的算法。在其他情形中，所有已知的可满足性判定算法的运行时间均随 N 指数增长。

3.3.6 着色与顶点覆盖

给定一个图和整数 q，著名的 q-着色问题询问能否用 q 种颜色为图的顶点着色，使任意由边连接的两个顶点颜色不同。类似地，顶点覆盖问题要求用尽可能少的“石子”覆盖顶点，使每条边至少有一个端点被石子覆盖。

3.3.7 数字划分

数字划分是一个不来自图论的例子。一个实例是由 N 个整数组成的集合 $S = \{x_1, \ldots, x_N\}$。一个构型将这些数划分为两组 A 和 $S \setminus A$。是否存在一个划分使得

$$\sum_{i \in A} x_i = \sum_{i \in S \setminus A} x_i \, ?$$

译注：原文同时用 S 表示数的集合、用 $i \in S$ 索引 x_i，这里照录；若将 S 视为指标集，则该求和记号更为一致。

3.4 计算复杂性理论初步

理论计算机科学的一个主要分支致力于建立内在的计算复杂性理论。例如，人们希望确定哪些问题比其他问题更困难。所谓“更困难”，是指求解所需的运行时间更长。为了严格讨论一个问题的计算复杂性，需要定义精确的计算模型（例如引入 Turing 机），但这会使我们离题太远。我们将以“基本操作”——比较、加法、乘法等——来估计算法的运行时间。只要操作数的大小始终有统一界限，这种非形式的方法基本正确。

3.4.1 最坏情况

如第 3.2 节所述，组合优化问题由其可能实例的集合定义。给定一个求解该问题的算法，即使实例“规模”固定，其运行时间也会因实例而异。应如何量化问题的整体难度？计算复杂性理论的一个关键选择是：在所有相同规模的实例中考虑“最坏”的实例，即求解时间最长的实例。

这一选择有两个优点：(i) 它允许建立一个“普适”的理论；(ii) 一旦估计出给定算法在最坏情况下的运行时间，便为该问题的任何实例提供性能保证。

3.4.2 是否为多项式？

第二个关键选择是将算法分为两类：(i) *多项式算法*，其运行时间有一个关于实例规模的固定多项式上界。用数学语言说，令 T_N 为在最坏情况下求解规模为 N 的实例所需的操作数。如果存在常数 k 使 $T_N = O(N^k)$，则算法是多项式的。(ii) *超多项式算法*，即不存在上述上界。

例如运行时间随实例规模指数增长的情况（我们称此类算法为指数算法），即对某个常数 k 有 $T_N = \Theta(k^N)$。[5]

例 3.3. *在第 3.1.2 节，我们证明了 MST 算法的运行时间以上界 N^3 为界，其中 N 是图的顶点数。因此该算法是多项式的。*

请注意，我们尚未精确定义问题的“规模”。人们可能会问，改变规模的定义后，同一个问题能否既被分类为多项式又被分类为超多项式？例如考虑有 $2N$ 个点的分配问题。规模可以定义为 N、$2N$，甚至可以定义为可能的人与工作配对数 N^2。例如，如果使用占据数 $n_{ij} \in \{0,1\}$，当且仅当工作 i 分配给人员 j 时 $n_{ij} = 1$，那么最后一种定义便是相关的。不过，这些“自然”的规模定义中任意两个互为多项式函数。因此，它们不影响算法是多项式还是超多项式的分类。我们将不再赘述地把其他定义（如 e^N 或 $N!$）排除为“不自然”的定义。读者可以用上一节的各个例子自行验证。[6]

3.4.3 优化、求值与判定

为了解它们相对困难程度，暂时回到第 3.2 节定义的三类优化问题，研究哪一类最困难。

显然，如果任意构型的代价都能在多项式时间内计算，那么求值问题不比优化问题更难：如果能够在多项式时间内找到最优构型，也能在多项式时间内计算其代价。判定问题（判断是否存在代价小于给定值 E_0 的构型）不比求值问题更难。因此按难度递增排列为：判定、求值、优化。

然而，在许多代价取离散值的情形中，求值问题也不比判定问题更难，意义如下。假设我们有求解判定问题的多项式算法，且所有构型的代价经缩放后都是区间 $[0, E_{\max}]$ 内的整数，其中区间长度满足 $E_{\max} = \exp\{O(N^k)\}$，$k > 0$。可以用判定算法通过二分法求解求值问题：首先取 $E_0 = E_{\max}/2$；如果存在能量小于 E_0 的构型，就以区间 $[0, E_{\max}/2]$ 的中点为下一次的 E_0；否则以 $[E_{\max}/2, E_{\max}]$ 的中点为下一次的 E_0。显然，这一过程也能在多项式时间内找到最优构型的代价。

3.4.4 多项式归约

我们希望比较不同判定问题的困难程度。*多项式归约*的概念将前面使用的“不比……更难”形式化，有助于对判定问题进行分类。

粗略地说，如果 A 的任何高效算法（假如存在）都可以用作高效求解 B 的算法中的子程序，我们就说问题 B 不比 A 更难。更准确地说，给定判定问题 A 和 B，若满足下列条件，则称 B 可以多项式归约到 A：

1. 存在映射 R，将问题 B 的任意实例 I 转换为问题 A 的实例 $R(I)$，使得 A 的实例 $R(I)$ 的解（是 / 否）给出 B 的实例 I 的解（是 / 否）。

2. 映射 $I \mapsto R(I)$ 可在关于 I 的规模的多项式时间内计算。

[5]译注：原文此处未明确限定指数底数 $k > 1$。

[6]译注：原文说这些定义互为多项式函数；严格说 N 并非 N^2 的多项式函数。分类不变所需的是相关规模之间存在适当的多项式上下界。

3. $R(I)$ 的规模是 I 的规模的多项式。事实上这由前述假设推出，但明确写出也无妨。

满足上述要求的映射 R 称为多项式归约。构造两个问题之间的多项式归约是一项重要成就，因为它实际上将两者的研究归结为只研究其中一个。假设有多项式算法 Alg_A 求解 A，那么可用从 B 到 A 的多项式归约构造求解 B 的多项式算法：给定 B 的实例 I，先计算 $R(I)$，将它交给 Alg_A，再输出 Alg_A 的结果。由于 $R(I)$ 的规模是 I 的规模的多项式，所得求解 B 的算法仍是多项式算法。

为具体说明，我们给出一个明确的例子：图中 Hamilton 圈的存在性问题可以多项式归约到可满足性问题。

例 3.4. *Hamilton* 圈问题的一个实例是具有 N 个顶点、标号为 $i \in \{1,\dots,N\}$ 的图。若图中存在 *Hamilton* 圈，可用 N^2 个布尔变量 $x_{ri} \in \{0,1\}$ 描述：若编号 i 的顶点是圈中的第 r 个顶点，则 $x_{ri}=1$，否则 $x_{ri}=0$（例如可取 $x_{11}=1$）。我们写出 *Hamilton* 圈存在时变量 x_{ri} 必须满足的一组约束，并保证这些约束具有可满足性问题所用的子句形式（$x=1$ 表示真，$x=0$ 表示假）：

- 每个顶点 $i \in \{1,\dots,N\}$ 必须属于该圈：可写为子句 $x_{1i} \vee x_{2i} \vee \cdots \vee x_{Ni}$，当且仅当 $x_{1i}, x_{2i}, \dots, x_{Ni}$ 中至少一个等于 *1* 时满足。
- 对每个 $r \in \{1,\dots,N\}$，必须有一个顶点是圈中第 r 个访问的顶点：$x_{r1} \vee x_{r2} \vee \cdots \vee x_{rN}$。
- 每个顶点 $i \in \{1,\dots,N\}$ 只能被访问一次。可通过 $N(N-1)/2$ 个子句 $\overline{x}_{rj} \vee \overline{x}_{sj}$（$1 \le r < s \le N$）实现。
- 对每个 $r \in \{1,\dots,N\}$，圈中第 r 个访问的顶点只能有一个。可通过 $N(N-1)/2$ 个子句 $\overline{x}_{ri} \vee \overline{x}_{rj}$（$1 \le i < j \le N$）实现。
- 对图中没有边连接的每一对顶点 $i<j$，这两个顶点不应在圈的顶点列表中相邻。因此，对每一对这样的顶点及每个 $r \in \{1,\dots,N\}$，加入子句 $\overline{x}_{ri} \vee \overline{x}_{(r+1)j}$ 和 $\overline{x}_{rj} \vee \overline{x}_{(r+1)i}$（采用循环约定 $N+1=1$）。

容易证明，以此方式构造的可满足性问题的规模是 *Hamilton* 圈问题规模的多项式。留给读者证明上述所有子句构成充分的约束：如果 N^2 个变量满足所有约束，它们就描述了一个 *Hamilton* 圈。

译注： 第三项原文先固定顶点 i，后在子句中使用 j；这里照录，须理解为对每个顶点分别施加对应子句。上述子句计数亦是每个固定顶点或固定位置的数量。

3.4.5 复杂性类

继续将注意力放在判定问题上。按照多项式性，这些问题分类如下：

- **P 类：** 这些是多项式问题，存在多项式时间运行的算法。例如，第 3.1 节的最小生成树问题的判定版本：给定一幅带边代价的图和一个数 E_0，是否存在总代价小于 E_0 的生成树？

- **NP 类：**这是非确定性多项式问题类，可以由“非确定性”算法在多项式时间内求解。粗略地说，这种算法可以在任意多的处理器上并行运行。这里不详细解释这个概念，而使用另一种等价刻画：如果存在一个可用来验证问题的“是”答案的“短”证书，就称该问题属于 NP 类。短证书是指可以在多项式时间内验证的证书。

  上述最小生成树这样的多项式问题自然属于 NP，故 $\mathrm{P} \subseteq \mathrm{NP}$。TSP 的判定版本也属于 NP：如果存在代价小于 E_0 的旅行商回路，短证书很简单，只需给出该回路，即可在线性时间内计算其代价并验证它小于 E_0。可满足性问题也属于 NP：满足所有子句的变量赋值给出一个证书。验证所有子句均满足所需时间与子句数（这里视为系统规模）成正比。事实上，NP 类有许多重要问题，其应用广泛，涵盖路径规划、调度、芯片验证、蛋白质折叠等。

- **NP 完全类：**这些是 NP 类中最困难的问题。一个问题是 NP 完全的，当且仅当：(i) 它属于 NP；(ii) NP 中任何其他问题都可以使用第 3.4.4 节定义的多项式归约归约到它。如果 A 是 NP 完全的，那么对 NP 中任何其他问题 B，都存在从 B 到 A 的多项式归约。因此如果有多项式算法求解 A，那么广泛的 NP 类中所有问题都能在多项式时间内求解。

NP 完全问题是否存在，事先并不显然。计算复杂性理论的一项重大成就是 Cook 于 1971 年得到的下述定理。

定理 3.5. *可满足性问题是 NP 完全的。*

这里不证明该定理。只指出可满足性问题有一种非常普适的结构（上面将 Hamilton 圈问题多项式归约到可满足性问题的例子已展示了这一点）。子句由一些变量或其否定的逻辑或（记作 $\vee$）构成。要求同时满足的若干子句构成这些子句的逻辑与（记作 $\wedge$）。因此可满足性问题一般写成 $(a_1 \vee a_2 \vee \cdots) \wedge (b_1 \vee b_2 \vee \cdots) \wedge \cdots$，其中 a_i, b_i 为“文字”，即原变量或其否定。这种形式称为合取范式（CNF）；容易看出，布尔变量之间的任何逻辑命题都可以写成 CNF。这种普适的分解可以让人理解为何可满足性问题能发挥核心作用。[7]

3.4.6 $\mathrm{P} = \mathrm{NP}$?

已知一个 NP 完全问题 A 时，可以比较容易地找到其他 NP 完全问题：如果存在从 A 到另一个问题 $B \in \mathrm{NP}$ 的多项式归约，则 B 也是 NP 完全的。事实上，若 $R_{A\leftarrow P}$ 是从问题 P 到 A 的多项式归约，而 $R_{B\leftarrow A}$ 是从 A 到 B 的多项式归约，则 $R_{B\leftarrow A} \circ R_{A\leftarrow P}$ 是从 P 到 B 的多项式归约。从可满足性问题出发，人们已经用这一方法找到数千个 NP 完全问题。在已遇到的问题中，例如 Hamilton 回路、TSP 和 3-可满足性（即子句长度均为 3 的可满足性问题）都是 NP 完全的。事实上，大多数 NP 问题可以归类为属于 P 或属于 NP 完全类。一些 NP 问题（例如图同构）的确切地位仍未知。最后，那些不属于 NP、但至少和 NP 完全问题一样困难的问题，通常称为 NP 困难问题。这包括不存在短证书的判定问题和非判定问题。例如，TSP 的优化和求值版本都是 NP 困难的。然而在这种情况下，我们会比较自由地选用“TSP 是 NP

[7]译注：此处关于验证时间的线性表述依赖输入表示；一般输入长度应计入各子句的文字总数。NP 证书刻画通常还需证书长度有多项式上界。

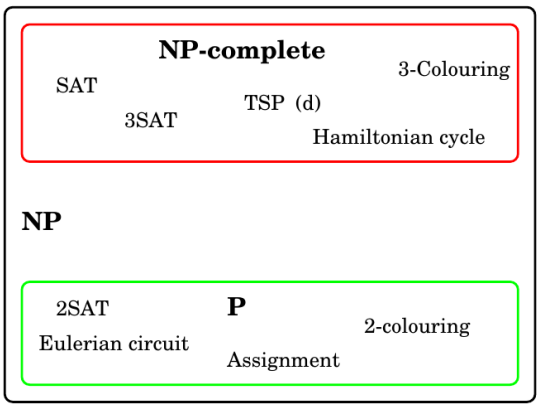


图 3.4: 一些著名判定问题的分类。若 $P \neq NP$，则 P 类与 NP 完全类不相交。若 $P = NP$，NP 中所有问题，特别是这里提到的全部问题，都可在多项式时间内求解。取自 Part A 草稿第 60 页。

完全的”或“TSP 是 NP 困难的”这两种表述。[8]

计算复杂性理论的一个重大开放问题是 P 类和 NP 类是否不同。可能有 P = NP = NP 完全类：如果有人找到一个 NP 完全问题的多项式算法，就会出现这种情况。这意味着广泛的 NP 类中没有任何问题可以在多项式时间内求解。[9]

一种广泛流行的猜想是 NP 完全问题不存在多项式算法。此时 P 类与 NP 完全类不相交。事实上已知，如果 $P \neq NP$，则存在既不属于 P 也不属于 NP 完全类的 NP 问题。

3.4.7 其他复杂性类

注意 NP 类定义中的基本不对称性：仅要求“是”答案存在短证书。为理解这一不对称性，考虑不可满足性问题（即可满足性问题的补问题），表述为：“给定一组子句，该问题是否不可满足?”目前尚不清楚是否存在可用于验证“是”答案的短证书：若不检查指数多个可能构型，就很难证明问题不能被满足。因此不可满足性属于 NP 并非显然。NP 中问题的补问题构成 co-NP 类；目前不知道 NP = co-NP 是否成立，尽管人们普遍相信 co-NP 与 NP 不同。这一考虑打开了包含众多其他复杂性类的潘多拉魔盒；但由于这会使我们离题太远，我们立即将它关上。

3.5 优化与统计物理

3.5.1 一般关系

优化问题到统计物理存在自然的映射。考虑一个由允许构型的有限集合 $\mathcal{X}$ 和定义在其上、取值于 $\mathbb{R}$ 的代价函数 E 所确定的优化问题。优化要求寻找代价最小的构型 $C \in \mathcal{X}$；我们可以

[8]译注：通常 NP 困难的定义并不要求问题位于 NP 之外；判定版本与优化版本也应区分。这里保留作者草稿表述。

[9]译注：末句按原文照录，但与前句及图 3.4 的说明相反；若存在所述算法，NP 中所有问题均可在多项式时间内求解。

在构型空间上引入 Boltzmann 型概率测度：对任意 β，为每个 C 赋予概率[10]

$$p_\beta(C) = \frac{1}{Z(\beta)} e^{-\beta E(C)}, \qquad Z(\beta) = \sum_{C \in \mathcal{X}} e^{-\beta E(C)}. \tag{3.1}$$

正参数 β 起逆温度的作用。在 $\beta \to \infty$ 的极限下，概率分布 p_β 集中于能量最小的构型（统计物理术语中的基态）。这是与优化问题相关的极限。在统计物理方法中，我们将问题推广为研究有限 β 时分布 p_β 的性质。在许多情况下，跟踪 β 增大时的 p_β 很有用（例如监测内能、熵和比热等热力学性质）。尤其当热力学性质平滑演化时，这对解析研究与算法设计都可能有用。模拟退火方法是一个实际应用例子：它在越来越大的 β 下对构型空间采样，直至找到基态。第 4 章将介绍此方法。当然，正如我们将看到的，相变的存在会给这类策略带来重大挑战。[11]

3.5.2 自旋玻璃与最大割

作为具体例子，回到第 2.6 节的自旋玻璃问题。考虑位于图的顶点上的 N 个 Ising 自旋 $\sigma_1, \dots, \sigma_N \in \{\pm 1\}$，能量函数为

$$E(\sigma) = -\sum_{(ij)} J_{ij} \sigma_i \sigma_j, \tag{3.2}$$

其中求和遍及图的所有边，J_{ij} 是可正可负的交换耦合。给定图和交换耦合，相应自旋玻璃的基态是什么？这是典型的优化问题。事实上，它以稍有不同的形式在计算机科学中广为人知。

每个自旋构型将顶点集划分为两个互补子集 $\mathcal{V}_\pm = \{i \mid \sigma_i = \pm 1\}$。记 $\gamma(\mathcal{V}_+)$ 为一端在 $\mathcal{V}_+$、另一端在 $\mathcal{V}_-$ 的边集。构型能量可写为

$$E(\sigma) = -C + 2 \sum_{(ij) \in \gamma(\mathcal{V}_+)} J_{ij}, \tag{3.3}$$

其中 $C = \sum_{(ij)} J_{ij}$。

因此寻找自旋玻璃的基态等价于寻找顶点划分 $\mathcal{V} = \mathcal{V}_+ \cup \mathcal{V}_-$，使 $\sum_{(ij) \in \gamma(\mathcal{V}_+)} c_{ij}$ 最大，其中 $c_{ij} \equiv -J_{ij}$。这称为最大割问题（MAX-CUT）：边集 $\gamma(\mathcal{V}_+)$ 是一个割，每个割被赋予权重 $\sum_{(ij) \in \gamma(\mathcal{V}_+)} c_{ij}$，目标是寻找权重最大的割。

关于最大割的标准结果立即适用：一般来说这是 NP 困难问题，但某些类别的图可以在多项式时间内求解。尤其是，平面图的最大割可在多项式时间内找到，从而为获得二维方格晶格自旋玻璃的基态提供高效方法。三维自旋玻璃问题属于一般的 NP 困难类，但近年来人们已基于其最大割表述发展了良好的“分支定界”方法。[12]

优化在物理中的另一个著名应用是随机场 Ising 模型：系统具有铁磁耦合（所有 J_{ij} 均为正），但磁场 h_i 随位置变化，可取正值或负值。由于它等价于寻找图中最大流的问题，可以在多项式时间内找到其基态。

---

[10] 注意，式 (3.1) 的直接推广并非唯一选择。一些问题的构型空间涉及硬约束，在有限温度版本中也可以放松这些约束。

[11] 译注：此处描述的是方法的目标；有限时间内是否找到基态取决于退火方案与具体问题，并非一般保证。

[12] 译注：此处映射使用式 (3.2) 的零外场哈密顿量；图是否平面亦取决于边界条件。

3.6 优化与编码

计算复杂性问题在所有信息论问题中也至关重要。本书会反复看到这一点，这里仅给出几个简短例子，以便建立直观认识。

考虑第 1 章的纠错码问题。一个码将原始消息映射为码字 x，即 N 维超立方体 $\{0,1\}^N$ 中的一个点。共有 2^M 个码字（$M<N$），假设它们先验等概率。当消息传输时，码字 x 以概率 $Q(y\mid x)$ 被扰动为向量 y。译码将收到的消息 y 映射为可能的原始码字之一 $x'=d(y)$。如前所述，一种性能度量是平均分组错误概率：

$$P_B^{\text{av}} \equiv \frac{1}{2^M}\sum_x \sum_y Q(y\mid x)\,\mathbf{1}\big(d(y)\neq x\big). \tag{3.4}$$

一种简单的译码算法是：对每个收到的消息 y，考虑全部 2^N 个码字，并确定其中最可能的一个：$d(y)=\arg\max_x Q(y\mid x)$。显然，该算法使平均分组错误概率最小。[13]

对于一般的码，最大化 $Q(y\mid x)$ 没有比遍历全部码字并逐一计算似然更好的方法。这需要约 2^M 的时间，显然过大。事实上，要实现可靠通信，M 和 N 必须足够大（数据传输应用中 N 可大至 10^5）。有人可能会反驳说，“译码一般的码”是一个过于一般的优化问题。即便要指定一个实例，也需要指定所有码字，耗费 $N2^M$ 比特。因此，译码的复杂性可能只是连读取输入都需要很长时间这一事实的直接后果。然而可以证明，即使对具有简洁描述（描述长度是分组长度的多项式）的码进行译码，也是 NP 困难的。后面几章将给出此类码的例子。

注释

本章撇开了大多数算法问题。尤其是，许多优化算法基于线性规划。对于代价函数和约束都是变量的线性函数的连续优化问题，有良好的理论框架和非常高效的求解算法。这些工具可成功用于处理离散变量的优化问题，思路是放松整数约束。例如，在 MAX-CUT 问题中，可为每条边 e 赋予一个值 $x_e\in\{0,1\}$，表示该边是否属于割。若 c_e 是边的代价，就需要在所有可行割上最大化 $\sum_e x_e c_e$。第一步是将整数约束 $x_e\in\{0,1\}$ 放松为 $x_e\in[0,1]$，扩大搜索空间，然后使用线性规划求解连续问题。如果最大值由整数 x_e 取得，就得到原离散问题的解；否则可加入额外约束再次缩小搜索空间，直到找到真正的 MAX-CUT。关于组合优化的一般介绍，包括上述所有方面，可参见 Papadimitriou 和 Steiglitz（1998）。[14]

关于计算复杂性理论的完整论述，可参见 Garey 和 Johnson（1979），或较近的 Papadimitriou（1994）。Cook 的开创性定理于 1973 年被 Levin 独立重新发现；读者可在上述著作中找到其证明。欧拉在 Euler（1736） 中讨论了柯尼斯堡七桥问题。

TSP 易于表述、求解困难且适于直观图示，吸引了大量研究。有兴趣的读者可从 Applegate、Bixby、Chvátal 和 Cook 的网络资料出发，找到许多参考文献、包含数千个顶点的最优旅行商回路图片（包括穿过各国主要城市的路线）、小程序等。[15]

---

[13]译注：原文此处写 2^N 个码字，而前文定义的是 2^M 个码字；2^N 是整个二元超立方体的点数。后文计算复杂度也使用 2^M。

[14]译注：线性规划表述还须指定描述可行割的约束；仅将每个变量限制于区间 $[0,1]$ 并不足以表征割。加入约束的过程及其终止与效率取决于具体方法。

[15]译注：作者草稿中该条文献未给出年份，Part F 该条也无年份，现已列入书后。

Hartmann 和 Rieger（2002）的著作侧重使用优化算法求解统计物理中的一些问题，尤其解释了如何用最大流算法确定随机场 Ising 模型的基态。同两位作者编辑的较近论文集 Hartmann 和 Rieger（2004）讨论了连接优化与物理的若干算法问题；其中 Liers、Jünger、Reinelt 和 Rinaldi 所写第 4 章介绍了用于自旋玻璃研究的最大割分支割平面方法。

编码理论中的经典计算问题可参见 Barg（1998）的综述；一些较近问题由 Spielman（1997）讨论。最后，译码问题的 NP 完全性最初由 Berlekamp、McEliece 和 van Tilborg（1978）证明。

第四章　概率工具箱

本书主题所涉及的三个领域都要处理大量随机变量。因此，它们具有共同的底层结构和技术并不令人意外。本章介绍其中一些方法，着重讨论两类数学结构：一类是大偏差，另一类是用于 Monte Carlo 计算的 Markov 链。这些工具将在后续章节中多次出现。

由于本章比前几章更具技术性，我们用整个第 4.1 节对主题作定性介绍。第 4.2 节考虑许多独立随机变量的简单函数的大偏差性质，此时容易得到许多显式结果。第 4.3 节给出处理相关随机变量的一些一般工具，第 4.4 节介绍 Gibbs 自由能的思想。第 4.5 节简要介绍从给定概率分布中抽取构型的 Markov 链 Monte Carlo 方法。最后，第 4.6 节说明模拟退火如何利用 Monte Carlo 技术求解优化问题。

4.1　多个随机变量：定性预览

考虑随机变量组 $x = (x_1, x_2, \ldots, x_N)$，其中 $x_i \in \mathcal{X}$，其依赖于 N 的概率分布为

$$P_N(x) = P_N(x_1, \ldots, x_N). \tag{4.1}$$

例如，这可以是具有 N 个自由度的物理系统的 Boltzmann 分布。该概率律的熵为 $H_N = -\mathbb{E}\log P_N(x)$。当 N 较大时，这个熵常常随 N 线性增长，即每个变量的熵 $h_N = H_N/N$ 有有限极限 $\lim_{N\to\infty} h_N = h$。因此，自然的做法是计算

$$f(x) = \frac{1}{N}\log\left[\frac{1}{P_N(x)}\right], \tag{4.2}$$

以描述随机变量 $(x_1, \ldots, x_N)$ 的任一具体实现，该量衡量事件 $(x_1, \ldots, x_N)$ 的概率。f 的期望为 $\mathbb{E}f(x) = h_N$。人们可能会问 $f(x)$ 是否涨落很大，还是其分布在 $f = h_N$ 附近高度集中。后一种假设在许多情况下成立：当 $N \gg 1$ 时，f 的概率分布 $Q_N(f)$ 常具有指数行为

$$Q_N(f) \doteq e^{-NI(f)}, \tag{4.3}$$

其中 $I(f)$ 在 $f = h$ 有非简并极小值，且 $I(h) = 0$。这意味着，以很大概率随机选出的构型 x 具有“接近” h 的 $f(x)$；根据定义 (4.2)，其概率近似为 $\exp(-Nh)$。由于满足 $f(x) \approx h$ 的实现的总概率接近 1，其数目必按 $\mathcal{N} \doteq \exp(Nh)$ 标度。换言之，全部概率由所有构型中很小的一部分承载（因为它们的数目 $\exp(Nh)$ 一般比 $|\mathcal{X}|^N$ 指数级地小），且这些构型具有相同的概率。这种性质通常称为“渐近均分性”，成立时会产生重要后果。[1]

[1]译注：上述“相同”和“接近”应按渐近、指数尺度理解；当熵密度达到 $\log|\mathcal{X}|$ 时，典型集合不一定是指数级小的比例。

例如，假设我们希望压缩变量 $(x_1,\dots,x_N)$ 中包含的信息，它们是一信息源产生的符号序列。显然应关注满足 $f(x)$ 接近 h 的“典型”序列 x，因为所有其他序列的概率趋于零。由于有 $\exp(Nh)$ 个这样的典型序列，只要为它们编号，就应能用 $Nh/\log 2$ 比特对其编码。

另一个非常一般的问题是从概率分布 $P_N(x)$ 采样。设 $x^1,\dots,x^r$ 是从 $P_N(x)$ 独立抽取的 r 个实现，则无需对 $|\mathcal{X}|^N$ 项求和，就可以用 $r^{-1}\sum_{k=1}^{r} O(x^k)$ 估计期望 $\mathbb{E}O(x)=\sum_x P_N(x)O(x)$；当 r 大时，精度通常按 $1/\sqrt{r}$ 改善。一种朴素的采样算法可以是：先从均匀分布 $P_N^{\mathrm{unif}}(x)=1/|\mathcal{X}|^N$ “提出”构型 x，这很容易采样；[2]然后以概率 $P_N(x)$ “接受”该构型。这个算法极其低效：对于“行为良好”的可观测量的期望，我们寻找的是 $f(x)$ 接近 h 的构型，但这样的构型指数级罕见，上述算法要经过约 $\exp[N(\log|\mathcal{X}|-h)]$ 的时间才能找到一个。Monte Carlo 方法将提供更好的替代方案。[3]

4.2 独立变量的大偏差

式 (4.3) 这样的行为是大偏差原理的一个例子。具有这种性质的系统经常出现，更一般的函数 $f(x)$ 也可能满足该性质。出现此类行为的最简单情形，也是能对所有性质作详细控制的情形，是独立随机变量。本节研究这一情形。

4.2.1 一组观测有多典型？

假设给定 N 个独立同分布随机变量的值 $s_1,\dots,s_N$，它们依照已知概率分布 $\{p(s)\}_{s\in\mathcal{X}}$ 从有限空间 $\mathcal{X}$ 中抽取。例如，s_i 可以由信息源产生，也可以来自对物理系统的重复测量。我们想知道序列 $s=(s_1,\dots,s_N)$ 是典型序列还是罕见事件。当 N 很大时，可以预期给定 $x\in\mathcal{X}$ 在典型序列中出现的次数接近 $Np(x)$。*型方法*使这一说法可以量化。

序列 s 的型 $q_s(x)$ 是符号 x 在该序列中出现的频率：

$$q_s(x)=\frac{1}{N}\sum_{i=1}^{N}\delta_{x,s_i}, \tag{4.4}$$

其中 δ 为 Kronecker 符号：若 $x=y$ 则 $\delta_{x,y}=1$，否则为 0。对任意观测 s，作为 x 的函数，型 $q_s(x)$ 具有 $\mathcal{X}$ 上概率分布的性质：对所有 $x\in\mathcal{X}$ 有 $q(x)\ge 0$，且 $\sum_x q(x)=1$。下文用 $\mathcal{M}(\mathcal{X})$ 表示 $\mathcal{X}$ 上概率分布的空间，

$$\mathcal{M}(\mathcal{X})\equiv\left\{q\in\mathbb{R}^{\mathcal{X}}:q(x)\ge 0,\ \sum_x q(x)=1\right\}.$$

因此 $q_s\in\mathcal{M}(\mathcal{X})$。型 $q_s(x)$ 的期望与原始概率分布一致：

$$\mathbb{E}\,q_s(x)=p(x). \tag{4.5}$$

Sanov 定理估计序列的型偏离 $p(x)$ 的概率。

---

[2]这里假设可以使用随机源：$\lceil N\log_2|\mathcal{X}|\rceil$ 个无偏随机比特足以从 $P_N^{\mathrm{unif}}(x)$ 采样。实际中通常用伪随机数发生器代替随机源。译注：若 $|\mathcal{X}|^N$ 不是 2 的幂，固定数量无偏比特通常不能无偏地精确采样该均匀分布。

[3]译注：所述指数尺度与从均匀分布提出典型构型的等待时间有关；若按原文另以 $P_N(x)$ 接受，则总接受率为 $|\mathcal{X}|^{-N}$，应与此区分。

定理 4.1 (Sanov)**.** 设 $x_1,\dots,x_N\in\mathcal{X}$ 为从概率分布 $p(x)$ 中抽取的 N 个独立同分布随机变量，$K\subset\mathcal{M}(\mathcal{X})$ 为 $\mathcal{X}$ 上概率分布组成的紧集。若 q 为 $(x_1,\dots,x_N)$ 的型，则

$$\mathrm{Prob}[q\in K]\doteq\exp[-ND(q^*\|p)],\tag{4.6}$$

其中 $q^*=\arg\min_{q\in K}D(q\|p)$，$D(q\|p)$ 为第 *1* 章定义的 *KL* 散度。

译注：原文把上式对任意紧集写为指数等价；一般的大偏差结果对闭集和开集分别给出上下界，完整极限还需适当的正则条件。例如只包含不可由有限样本型实现的单点集合时，上式不一定成立。这里保留草稿陈述。

基本上，该定理表明：出现型为 q 的序列的概率，在大 N 时按 $\exp[-ND(q\|p)]$ 标度。因此，当 N 很大时，典型序列具有型 $q(x)=p(x)$，其他型的序列指数级罕见。⋆定理的证明直接应用 Stirling 公式，留给读者作为习题。第 4.7 节附录使用物理中常用的“场论”方法给出推导；对想熟悉这类物理学家常用技术的读者，它可能是一个有益的简单例子。[4]

例 4.2. 设 x_i 是一枚偏置硬币的结果：$\mathcal{X}=\{$正面,反面$\}$，$p($正面$)=1-p($反面$)=0.8$。投掷 *100* 次出现 *50* 次正面和 *50* 次反面的概率是多少？在式 (4.6) 和第 *1* 章的 *KL* 散度公式中取 $N=100$、$q($正面$)=q($反面$)=0.5$，得到 $\mathrm{Prob}[50\text{ 次反面}]\approx 2.04\cdot10^{-10}$。

例 4.3. 考虑相反情形：取一枚公平硬币，$p($正面$)=p($反面$)=0.5$，询问出现 *80* 次正面和 *20* 次反面的概率。*Sanov* 定理给出估计 $\mathrm{Prob}[80\text{ 次正面}]\approx 4.27\cdot10^{-9}$，远高于前一例中算得的值。

译注：上述数值是仅保留指数率的估计，并非精确二项分布概率；有限 N 的多项式前因子未包含在内。

例 4.4. 大气柱的一个简单模型是研究地球重力场中的 N 个粒子。粒子 $i\in\{1,\dots,N\}$ 的状态由单一坐标 $z_i\geq0$ 给出，它测量粒子相对地面的高度。为简单起见，假设 z_i 为整数，例如可以用某个小长度单位（如毫米）将高度离散化。适当选择单位后，N 粒子的能量函数为

$$E=\sum_{i=1}^{N}z_i.\tag{4.7}$$

构型 $\{x_1,\dots,x_N\}$ 的型可以解释为该构型的密度剖面 $\rho(z)$：

$$\rho(z)=\frac{1}{N}\sum_{i=1}^{N}\delta_{z,z_i}.\tag{4.8}$$

由 *Boltzmann* 概率分布容易计算出通常称为“平衡”剖面的期望密度：

$$\rho_{\mathrm{eq}}(z)\equiv\langle\rho(z)\rangle=(1-e^{-\beta})e^{-\beta z}.\tag{4.9}$$

在某个时刻对 N 个粒子拍摄快照，其密度会相对 $\rho_{\mathrm{eq}}(z)$ 有所偏离。观察到密度剖面 $\rho(z)$ 的概率由式 (4.6) 给出，其中 $p(z)=\rho_{\mathrm{eq}}(z)$、$q(z)=\rho(z)$。例如可以计算观察到参数不同的指数密度剖面 $\rho_\lambda(x)=(1-e^{-\lambda})e^{-\lambda x}$ 的概率。使用 *KL* 散度公式得到

$$D(\rho_\lambda\|\rho_{\mathrm{eq}})=\log\left(\frac{1-e^{-\lambda}}{1-e^{-\beta}}\right)+\frac{\beta-\lambda}{e^{\lambda}-1}.\tag{4.10}$$

函数 $I_\beta(\lambda)\equiv D(\rho_\lambda\|\rho_{\mathrm{eq}})$ 如图 *4.1* 所示。

[4]译注：有限样本的型只能取分母为 N 的有理值；“型等于 p”及固定型的说法一般需按邻域或可实现型序列理解。

译注：此例的高度空间为可数无限集，而上述定理按原文只对有限空间陈述；将其用于此处需要额外条件。有限 N 的经验剖面与具有无限支集的指数分布也不能严格相等，应按邻域理解。

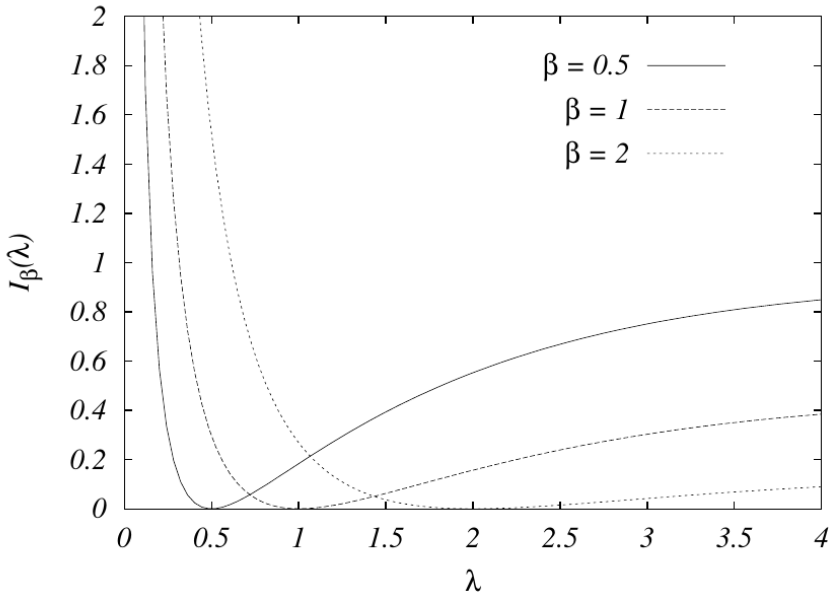


图 4.1: 例 4.4：平衡密度剖面为 $\rho_{\mathrm{eq}}(z) \propto e^{-\beta z}$ 的大气中，粒子数 N 很大时观察到非典型剖面 $\rho(z) \propto e^{-\lambda z}$ 的概率为 $\exp[-NI_\beta(\lambda)]$。图示 $I_\beta(\lambda)$ 表明 λ 很小的情形十分罕见。取自 Part A 草稿第 70 页。

习题 4.1. 前例容易推广到任意势 $V(x)$ 中 N 个粒子的密度剖面。证明 *Kullback–Leibler* 散度具有形式

$$D(\rho\|\rho_{\mathrm{eq}}) = \beta \sum_x V(x)\rho(x) - \sum_x \rho(x)\log\rho(x) + \log z(\beta). \tag{4.11}$$

译注：式 (4.11) 的熵项符号按原文保留；按照 $D(\rho\|\rho_{\mathrm{eq}}) = \sum_x \rho(x)\log[\rho(x)/\rho_{\mathrm{eq}}(x)]$ 与 $\rho_{\mathrm{eq}} \propto e^{-\beta V}$，该项应为 $+\sum_x \rho(x)\log\rho(x)$，有待原作者版本核对。

4.2.2 经验平均有多典型？

结果 (4.6) 包含有关随机变量 $\{x_i\}$ 大涨落的详细信息。我们常常希望关注某个测量量的经验平均的涨落，其中测量量是实值函数 $f(x)$：

$$\overline{f} = \frac{1}{N}\sum_{i=1}^{N} f(x_i). \tag{4.12}$$

当然，$\overline{f}$ 以高概率“接近” $\mathbb{E}f(x)$。下述结果定量描述罕见涨落的概率。

推论 4.5. 设 $x_1, \ldots, x_N$ 为从分布 $p(x)$ 中抽取的 N 个独立同分布随机变量，$f : \mathcal{X} \to \mathbb{R}$ 为实

值函数，$\overline{f}$ 为其经验平均。若 $A \subset \mathbb{R}$ 为实轴上的闭区间，则

$$\mathrm{Prob}[\overline{f} \in A] \doteq \exp[-NI(A)], \tag{4.13}$$

$$I(A) = \min_{q} \left\{ D(q\|p) \;\middle|\; \sum_{x\in\mathcal{X}} q(x)f(x) \in A \right\}. \tag{4.14}$$

证明. 对紧集

$$K = \left\{ q \in \mathcal{M}(\mathcal{X}) \;\middle|\; \sum_{x\in\mathcal{X}} q(x)f(x) \in A \right\} \tag{4.15}$$

应用定理 4.1，直接得到式 (4.13)，其中

$$I(\varphi) = \min_{q} \left\{ D(q\|p) \;\middle|\; \sum_{x\in\mathcal{X}} q(x)f(x) = \varphi \right\}. \tag{4.16}$$

上式中的最小值可用 Lagrange 乘数法求出，得到式 (4.14)。 □

译注：此推论依赖定理 4.1 所述指数等价的适用条件；对任意闭区间，尤其是单点区间，不能未经条件直接断言完整极限。上式 (4.16) 是点值率函数，集合率函数还须对 $\varphi \in A$ 取最小值。

例 4.6. 再次考虑例 4.4 中重力场内的 N 个粒子，并考察粒子的平均高度

$$\overline{z} = \frac{1}{N}\sum_{i=1}^{N} z_i. \tag{4.17}$$

该量的期望为 $\mathbb{E}(\overline{z}) = z_{\mathrm{eq}} = (e^{\beta}-1)^{-1}$。利用上述推论容易计算 $\overline{z}$ 的涨落概率。对 $z > z_{\mathrm{eq}}$，得到 $P[\overline{z} > z] \doteq \exp[-NI(z)]$，其中

$$I(z) = (1+z)\log\left(\frac{1+z_{\mathrm{eq}}}{1+z}\right) + z\log\left(\frac{z}{z_{\mathrm{eq}}}\right). \tag{4.18}$$

类似地，对 $z < z_{\mathrm{eq}}$，有 $P[\overline{z} < z] \doteq \exp[-NI(z)]$，率函数 $I(z)$ 相同。图 4.2 描绘了函数 $I(z)$。

习题 4.2. 可用能量函数为式 (4.7) 的 N 个粒子系统制作温度计。每当需要测温时，拍摄 N 个粒子的快照，计算 $\overline{x}$ 并利用公式 $(e^{\beta_{\mathrm{est}}}-1)^{-1} = \overline{x}$ 估计逆温度 β_{est}。当 $N \gg 1$ 时，得到 $\beta_{\mathrm{est}} \neq \beta$ 的概率是多少？

译注：习题改用 $\overline{x}$ 表示测量平均量，前例记作 $\overline{z}$；若严格要求估计值不等于 β，该事件并非固定幅度偏差，须与大偏差概率区分。

4.2.3 渐近均分性

上述工具也可用于计数型为给定 $q(x)$ 或某可观测量 f 的经验平均为给定值的构型 $s = (s_1, \ldots, s_N)$。例如得到：

命题 4.7. 型属于紧集 $K \subset \mathcal{M}(\mathcal{X})$ 的序列 s 的数目 $N_{K,N}$ 满足 $N_{K,N} \doteq \exp\{NH(q^*)\}$，其中 $q^* = \arg\max\{H(q) \mid q \in K\}$。

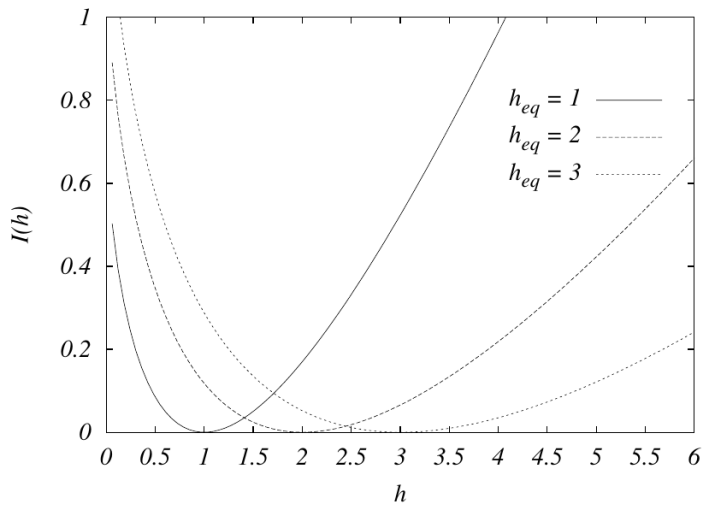


图 4.2: 能量函数为式 (4.7) 的 N 个粒子出现非典型平均高度的概率。取自 Part A 草稿第 71 页；图中 h、$h_{\rm eq}$ 分别对应正文的高度 z、$z_{\rm eq}$。

非形式地说，这一结果表示“型为 q 的序列约有 $e^{NH(q)}$ 个”。

证明. 思路是应用 Sanov 定理，取“参考”分布 $p(x)$ 为均匀分布 $p_{\rm flat}(x) = 1/|\mathcal{X}|$。由式 (4.6) 得到

$$N_{K,N} = |\mathcal{X}|^N \,\mathrm{Prob}_{\rm flat}[q \in K] \doteq \exp\{N \log|\mathcal{X}| - ND(q^*\|p_{\rm flat})\} = \exp\{NH(q^*)\}. \tag{4.19}$$

□

译注： 和定理 4.1 一样，任意紧集可能不含可实现的有限样本型；上述指数等价需要相应正则条件。

现在回到服从概率分布 $p(x)$ 的 N 个独立同分布变量构成的一般序列 $s = (s_1, \ldots, s_N)$。根据 Sanov 定理，最可能的型是 $p(x)$ 本身，偏离它的型在 N 中指数级罕见。我们预期几乎所有概率集中于其型在某种意义上接近 $p(x)$ 的序列。另一方面，根据上述命题，这些序列的数目比可能序列总数 $|\mathcal{X}|^N$ 指数级小。[5]

可以定义序列的型“接近 $p(x)$”的含义，使这些说法更精确。给定序列 s，引入

$$r(s) \equiv -\frac{1}{N}\log P_N(s) = -\frac{1}{N}\sum_{i=1}^{N}\log p(x_i). \tag{4.20}$$

显然 $\mathbb{E}r(s) = H(p)$。若且唯若 $|r(s) - H(p)| \le \varepsilon$，称序列 s 为 ε-典型序列。记 $\mathcal{T}_{N,\varepsilon}$ 为 ε-典型序列集合，它具有如下性质：

定理 4.8. *1.* $\lim_{N\to\infty}\mathrm{Prob}[s \in \mathcal{T}_{N,\varepsilon}] = 1$。

2. 当 N 充分大时，$e^{N[H(p)-\varepsilon]} \le |\mathcal{T}_{N,\varepsilon}| \le e^{N[H(p)+\varepsilon]}$。

3. 对任意 $s \in \mathcal{T}_{N,\varepsilon}$，$e^{-N[H(p)+\varepsilon]} \le P_N(s) \le e^{-N[H(p)-\varepsilon]}$。

[5]译注：当 p 为均匀分布时，后一指数级小的说法不成立。

证明. 由于 $r(s)$ 是经验平均，可应用推论 4.5，得到非典型序列概率的估计 $\mathrm{Prob}[s \notin \mathcal{T}_{N,\varepsilon}] \doteq \exp(-NI)$。指数为 $I = \min_q D(q\|p)$，最小值遍及满足

$$\left| \sum_{x \in \mathcal{X}} q(x) \log[1/q(x)] - H(p) \right| \geq \varepsilon$$

的全部概率分布 $q(x)$。但除非 $q = p$，否则 $D(q\|p) > 0$；而 p 不属于该最小化范围。因此 $I > 0$，且 $\lim_{N\to\infty} \mathrm{Prob}[s \notin \mathcal{T}_{N,\varepsilon}] = 0$，证明了 (1)。

对 ε-典型序列的型 $q(x)$ 的条件可改写为 $|D(q\|p) + H(q) - H(p)| \leq \varepsilon$。因此，对任意 ε-典型序列都有 $|H(q) - H(p)| \leq \varepsilon$，命题 4.7 便给出 (2)。最后，(3) 直接由 ε-典型序列的定义得到。 □

译注： 上述证明按草稿保留，但非典型事件的约束应涉及 $\sum_x q(x)\log[1/p(x)]$，而非 $H(q)$；由 $|D(q\|p) + H(q) - H(p)| \leq \varepsilon$ 也不能直接推出 $|H(q) - H(p)| \leq \varepsilon$。此外，原文的 (2) 下界没有通常证明中有限 N 的概率前因子，需单独核实其精确陈述。

上述命题所描述的行为通常称为*渐近均分性质*。尽管我们对独立同分布随机变量证明了它，但它不只在此类情形中有望成立。事实上，本书将会在许多有趣的系统中遇到它。

4.3 相关变量

对于有限空间上的独立随机变量，大涨落的概率容易通过组合方法计算。我们希望能对非独立随机变量的大偏差得到一些一般结果。本节介绍如何使用 Legendre 变换和鞍点方法研究一般情况。正如常见的那样，这种方法对应一个精确的数学陈述：Gärtner–Ellis 定理。我们先非形式地描述该方法并将其应用于几个例子，然后陈述和讨论定理。

4.3.1 Legendre 变换

具体考虑一组随机变量 $x = (x_1, \ldots, x_N)$，其中 $x_i \in \mathcal{X}$，其依赖 N 的概率分布为

$$P_N(x) = P_N(x_1, \ldots, x_N). \tag{4.21}$$

设 $f : \mathcal{X} \to \mathbb{R}$ 是实值函数。我们想估计大 N 时其经验平均的概率分布，

$$\overline{f}(x) = \frac{1}{N} \sum_{i=1}^{N} f(x_i). \tag{4.22}$$

上一节研究了 x_i 独立同分布的特殊情况，并证明相当一般地说，$\overline{f}(x)$ 的有限幅度涨落出现的概率呈指数衰减。自然可以预期，如果 x_i “弱相关”，同一结论仍成立。当 $P_N(x)$ 是某个物理系统的 Gibbs–Boltzmann 分布时，这一预期得到物理直觉支持。我们可以将 x_i 看作构成系统的微观自由度，将 $\overline{f}(x)$ 看作宏观可观测量（压强、磁化强度等）。一个常见观察是宏观可观测量的相对涨落很小。

因此假设 $\overline{f}$ 的分布满足大偏差原理，即分布在大 N 时的渐近行为为

$$P_N(\overline{f}) \doteq \exp[-NI(\overline{f})], \tag{4.23}$$

其中率函数 $I(\overline{f}) \geq 0$。为确定 $I(\overline{f})$，一种有用的方法是“倾斜”测度 $P_N(\cdot)$，使造成 $\overline{f}$ 的 $O(1)$ 涨落的罕见事件变得可能。具体而言，定义 $\overline{f}$ 的（对数）矩母函数为

$$\psi_N(t) = \frac{1}{N} \log \mathbb{E}\Big(e^{Nt\overline{f}(x)} \Big), \qquad t \in \mathbb{R}. \tag{4.24}$$

当性质 (4.23) 成立时，可用鞍点法计算 $\psi_N(t)$ 的大 N 极限：

$$\lim_{N\to\infty} \psi_N(t) = \lim_{N\to\infty} \frac{1}{N} \log \left\{ \int e^{Nt\overline{f} - NI(\overline{f})}\, d\overline{f} \right\} = \psi(t), \tag{4.25}$$

$$\psi(t) = \sup_{\overline{f}\in\mathbb{R}} \big[t\overline{f} - I(\overline{f}) \big]. \tag{4.26}$$

$\psi(t)$ 是 $I(\overline{f})$ 的 Legendre 变换，并且按构造是 t 的凸函数（可通过对式 (4.24) 求两次导数证明）。因此自然可以如下反转 Legendre 变换：

$$I_\psi(\overline{f}) = \sup_{t\in\mathbb{R}} \big[t\overline{f} - \psi(t) \big], \tag{4.27}$$

我们预期 $I_\psi(\overline{f})$ 与 $I(\overline{f})$ 的凸包络一致。当计算 $\psi(t)$ 比直接估计概率分布 $P_N(\overline{f})$ 容易时，该方法很有用。[6]

4.3.2 例子

考虑几个例子有助于建立直观认识。

例 4.9. *考虑无外磁场的一维 Ising 模型，参见第 2.5.1 节。确切地说，取 $x_i = \sigma_i \in \{+1, -1\}$，$P_N(\sigma) = \exp[-\beta E(\sigma)]/Z$ 为 Boltzmann 分布，其中能量函数为*

$$E(\sigma) = -\sum_{i=1}^{N-1} \sigma_i \sigma_{i+1}. \tag{4.28}$$

我们希望计算磁化强度

$$m(\sigma) = \frac{1}{N} \sum_{i=1}^{N} \sigma_i \tag{4.29}$$

的大偏差性质。由第 2.5.1 节及能量函数在自旋反转 $\sigma_i \to -\sigma_i$ 下的对称性可知 $\langle m(\sigma) \rangle = 0$。为计算 m 大幅涨落的概率，应用上述方法。稍加思考可知 $\psi(t) = \phi(\beta, t/\beta) - \phi(\beta, 0)$，其中 $\phi(\beta, B)$ 是第 2 章求出的、外磁场为 B 时模型的自由能密度。因此得到

$$\psi(t) = \log \left(\frac{\cosh t + \sqrt{\sinh^2 t + e^{-4\beta}}}{1 + e^{-2\beta}} \right). \tag{4.30}$$

可见，对任意 $\beta < \infty$，$\psi(t)$ 均为凸且解析的函数。利用式 (4.27) 可得到率函数 $I_\psi(m)$。图 4.3 给出了若干温度下所得函数。注意，对任意 m 及 $\beta < \infty$，$I_\psi(m)$ 都解析且二阶导数严格为正，因此预期 $I(m) = I_\psi(m)$。下文定理 4.12 证实了这一预期。

译注： 磁化强度位于 $[-1, 1]$；端点及区间外的率函数需要分别处理，原文“任意 m 均解析”的表述不能不加限制地理解。

[6] 译注：从大偏差原理通过鞍点或 Laplace 原理得到生成函数极限，需要相应的可积性和尾部条件；双重 Legendre–Fenchel 变换一般得到下半连续凸包络。

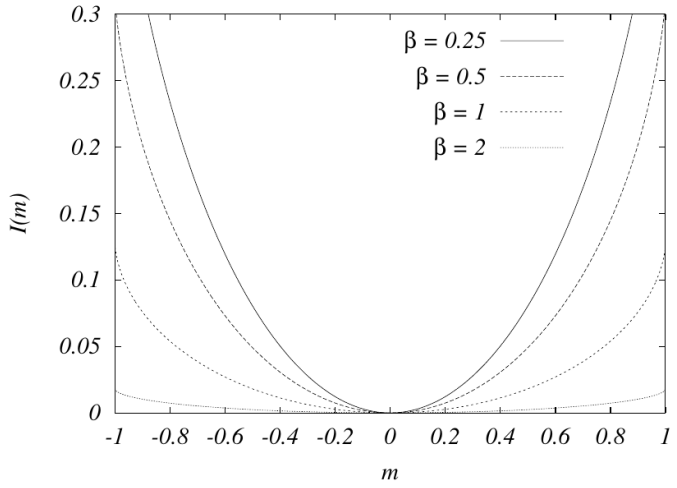


图 4.3: 一维 Ising 模型磁化强度的率函数。随着温度降低（β 增大），大涨落的概率增加。取自 Part A 草稿第 76 页。

例 4.10. *考虑取值于有限状态空间 $\mathcal{X}$ 的 Markov 链 $X_0, X_1, \ldots, X_i, \ldots$，如第 1.3 节的例 2，并假设转移矩阵 $w(x \to y)$ 的所有元素严格为正。研究经验平均 $N^{-1}\sum_i f(X_i)$ 的大偏差性质。*

可以证明，极限矩母函数 $\psi(t)$（见式 (4.24)）存在，且可由下述方法计算。定义“倾斜”转移概率 $w_t(x \to y) = w(x \to y)\exp[tf(y)]$。令 $\lambda(t)$ 为本征值问题的最大解：

$$\sum_{x\in\mathcal{X}} \varphi_t^l(x) w_t(x \to y) = \lambda(t)\varphi_t^l(y). \tag{4.31}$$

矩母函数直接由 $\psi(t) = \log\lambda(t)$ 给出；根据 Perron–Frobenius 定理，该本征值唯一且为正。

注意式 (4.31) 类似于转移概率为 $w_t(x \to y)$ 的 Markov 链的平稳条件。不幸的是，转移率 $w_t(x \to y)$ 没有正确归一化（$\sum_y w_t(x \to y) \neq 1$）。这一问题可如下克服。记 $\varphi_t^r(x)$ 为 $w_t(x \to y)$ 对应本征值 $\lambda(t)$ 的右本征向量，定义

$$\overline{w}_t(x \to y) \equiv \frac{1}{\lambda(t)\varphi_t^r(x)} w_t(x \to y)\varphi_t^r(y). \tag{4.32}$$

留给读者证明：(i) 这些转移率正确归一化；(ii) 对转移率 $\overline{w}_t(x \to y)$，式 (4.31) 确实是分布 $p_t(x) \propto \varphi_t^l(x)\varphi_t^r(x)$ 的平稳条件。

译注： 严格说，式 (4.31) 是倾斜矩阵的左本征向量方程；结合左右本征向量才得到 $\overline{w}_t$ 对 p_t 的平稳条件。w_t 本身一般不是概率转移矩阵。

例 4.11. *考虑无外场的 Curie–Weiss 模型，参见第 2.5.2 节。与例 4.9 一样，取 $x_i = \sigma_i \in \{+1, -1\}$ 和 $P_N(\sigma) = \exp[-\beta E(\sigma)]/Z$，研究整体磁化强度 (4.29) 的大涨落。能量函数为*

$$E(\sigma) = -\frac{1}{N}\sum_{(ij)} \sigma_i\sigma_j. \tag{4.33}$$

重复第 2.5.2 节的论证，容易证明，对任意 $-1 \le m_1 < m_2 \le 1$，

$$P_N\{m(\sigma) \in [m_1, m_2]\} \doteq \frac{1}{Z_N(\beta)} \int_{m_1}^{m_2} dm\, e^{N\phi_{\mathrm{mf}}(m;\beta)}, \tag{4.34}$$

其中 $\phi_{\mathrm{mf}}(m;\beta)=\frac{\beta}{2}m^2-\log[2\cosh(\beta m)]$。大偏差性质 (4.23) 成立，且

$$I(m)=\phi_{\mathrm{mf}}(m^*;\beta)-\phi_{\mathrm{mf}}(m;\beta), \tag{4.35}$$

$m^*(\beta)$ 是 *Curie–Weiss* 方程 $m=\tanh(\beta m)$ 的最大解。图 *4.4* 左图对几个逆温度给出了 $I(m)$。当 $\beta<\beta_c=1$ 时，$I(m)$ 是凸函数，且在 $m=0$ 有唯一极小值。

当 $\beta>\beta_c$ 时出现新的有趣情形：$I(m)$ 不再凸，在 $m=\pm m^*(\beta)$ 有两个简并极小值。换言之，系统可以处在两个明显不同的“态”之一：正磁化态和负磁化态。不再存在唯一的磁化强度典型值，使得远离该值的大涨落指数级罕见。

现在看看采用生成函数方法时会发生什么。不难看出极限 (4.24) 存在，且为

$$\psi(t)=\sup_{m\in[-1,1]}[mt-I(m)]. \tag{4.36}$$

高温 $\beta<1$ 时 $\psi(t)$ 凸且解析，而当 $\beta>1$ 时，它在 $t=0$ 出现奇异性。特别地，$\psi'(0+)=m^*(\beta)=-\psi'(0-)$。现在利用式 (4.27) 计算 $I_\psi(m)$。稍加思考可知，对任意 $m\in[-m^*(\beta),m^*(\beta)]$，上确界在 $t=0$ 取得，得到 $I_\psi(m)=0$。在该区间之外，上确界在 $\psi'(t)=m$ 的唯一解处取得，而 $I_\psi(m)$。正如预期，$I_\psi(m)$ 是 $I(m)$ 的凸包络。在区间 $(-m^*(\beta),m^*(\beta))$ 内，使用函数 $\doteq\exp[-NI_\psi(m)]$ 估计磁化强度涨落会高估该涨落。

译注： 上例保留草稿原式与末段不完整句。按原文给出的 $\phi_{\mathrm{mf}}=\beta m^2/2-\log[2\cosh(\beta m)]$，式 (4.34) 的指数符号及式 (4.35) 与所述极小值性质存在不一致；而第 2 章相关表达涉及辅助场的鞍点变量，不能未经推导直接当作磁化强度的概率率函数。这里不静默修正，需独立重推和对照正式版本。

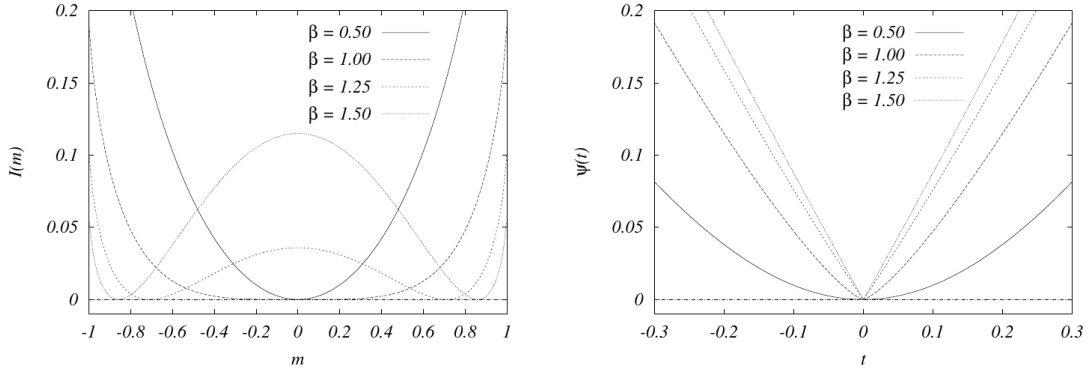


图 4.4: Curie–Weiss 模型中磁化强度大涨落的率函数（左）与相应生成函数（右）。取自 Part A 草稿第 81 页。

4.3.3 Gärtner–Ellis 定理

Gärtner–Ellis 定理有多种表述，通常需要预先给出一些技术性定义。这里采用一种简化（且有所削弱）的形式，只需定义暴露点：若存在 $t\in\mathbb{R}$，使得对任意 $y\neq x$ 都有 $ty-F(y)>tx-F(x)$，则 $x\in\mathbb{R}$ 是函数 $F:\mathbb{R}\to\mathbb{R}$ 的暴露点。例如，如果 F 为凸函数，x 是暴露点的充分条件是 F 在 x 处二次可微且 $F''(x)>0$。**译注：** 暴露点定义中的不等号按原文照录；它要求 x 严格小于

其他点的 $ty - F(y)$，与后述凸函数的充分条件及通常的暴露点定义不符，后者要求 x 是该表达式的严格最大点。

定理 4.12 (Gärtner–Ellis)**.** *考虑函数 $f(x)$（不一定具有式 (4.22) 的形式），假设式 (4.24) 定义的矩母函数 $\psi_N(t)$ 存在，且对任意 $t \in \mathbb{R}$ 有有限极限 $\psi(t) = \lim_{N\to\infty} \psi_N(t)$。定义 $I_\psi(\cdot)$ 为式 (4.27) 的逆 Legendre 变换，令 $\mathcal{E}$ 为 $I_\psi(\cdot)$ 的暴露点集合。*

1. *对任意闭集 $F \subset \mathbb{R}$，*

$$\limsup_{N\to\infty} \frac{1}{N} \log P_N(f \in F) \le - \inf_{f\in F} I_\psi(f). \tag{4.37}$$

2. *对任意开集 $G \subset \mathbb{R}$，*

$$\limsup_{N\to\infty} \frac{1}{N} \log P_N(f \in G) \ge - \inf_{f\in G\cap\mathcal{E}} I_\psi(f). \tag{4.38}$$

3. *如果进一步假设 $\psi(t)$ 对任意 $t \in \mathbb{R}$ 均可微，那么上一条中的下确界可在整个集合 G 上而不是 $G \cap \mathcal{E}$ 上取。*

译注： 式 (4.38) 按原文写 $\limsup$；通常大偏差下界的强形式使用 $\liminf$，故此处不把草稿表述当作已核准的标准定理。第 2、3 项还依赖暴露点定义及定理适用条件。

非形式地说，逆 Legendre 变换 (4.27) 一般给出宏观可观测量大涨落概率的上界。除非出现“一阶相变”（对应 $\psi(t)$ 的一阶导数不连续），该上界是紧的。

值得一提的是，$\psi(t)$ 可在某点 t^* 不解析，但其一阶导数在 t^* 连续。在统计力学术语中，这对应“高阶”相变。正如后续章节将看到的，这种现象也有有趣的概率解释。

4.3.4 典型序列

回到第 4.2.3 节引入的典型序列概念。更具体地说，我们希望研究概率本身的大偏差，以 $r(x) = -N^{-1}\log P(x)$ 衡量。对于独立随机变量，第 4.2.3 节的研究引出了 ε-典型序列。对于一般序列又能说些什么？

计算相应的矩母函数 (4.24)：

$$\psi_N(t) = \frac{1}{N} \log \left\{ \sum_x P_N(x)^{1-t} \right\}. \tag{4.39}$$

不失一般性，可假设 $P_N(x)$ 具有 Boltzmann 形式：

$$P_N(x) = \frac{1}{Z_N(\beta)} \exp\{-\beta E_N(x)\}, \tag{4.40}$$

其中 $E_N(x)$ 为能量函数。将其代入式 (4.39)，得到

$$\psi_N(t) = \beta f_N(\beta) - \beta f_N\big(\beta(1-t)\big), \tag{4.41}$$

其中 $f_N(\beta) = -(1/N)\log Z_N(\beta)$ 是逆温度为 β、能量函数为 $E_N(x)$ 的系统的自由能密度。假设热力学极限 $f(\beta) = \lim_{N\to\infty} f_N(\beta)$ 存在且有限，则极限生成函数 $\psi(t)$ 存在，可应用 Gärtner–Ellis 定理计算 $r(x)$ 大涨落的概率。只要 $f(\beta)$ 解析，大涨落就受到指数压制，独立随机变量的

渐近均分性质基本恢复。另一方面，如果在 $\beta=\beta_c$ 发生相变，$f(\beta)$ 的一阶导数在此不连续，则似然 $r(x)$ 可能以不消失的概率取若干不同的值。这正是上面的例 3 中磁化强度发生的情况。[7]

4.4 Gibbs 自由能

在第 2 章统计物理导论中，我们假设物理系统构型的概率分布为 Boltzmann 分布。事实上，这一分布可以从变分原理得到。这既有原理上的意义，也有助于寻找近似方案。

考虑构型空间 $\mathcal{X}$，其上的实值能量函数为 $E(x)$。

系统的 Boltzmann 分布为 $P_\beta(x)=\exp[-\beta(E(x)-F(\beta))]$，其中“自由能” $F(\beta)$ 是逆温度 β 的函数，由归一化条件 $\sum_{x\in\mathcal{X}}P_\beta(x)=1$ 确定。定义 *Gibbs 自由能* $G[P]$（不要与 $F(\beta)$ 混淆）为 $\mathcal{X}$ 上概率分布 $P(x)$ 空间上的实值泛函：

$$G[P]=\sum_{x\in\mathcal{X}}P(x)E(x)+\frac{1}{\beta}\sum_{x\in\mathcal{X}}P(x)\log P(x). \tag{4.42}$$

容易用 $P(x)$ 与 Boltzmann 分布 $P_\beta(x)$ 之间的 KL 散度重写 Gibbs 自由能：

$$G[P]=\frac{1}{\beta}D(P\|P_\beta)+F(\beta). \tag{4.43}$$

这一表示直接蕴含下述命题（*Gibbs 变分原理*）：

命题 4.13. *Gibbs 自由能 $G[P]$ 是 $P(x)$ 的凸泛函，并且在 Boltzmann 分布 $P(x)=P_\beta(x)$ 上达到唯一最小值。此外，$G[P_\beta]=F(\beta)$，其中 $F(\beta)$ 是自由能。*

当系统的配分函数不能精确计算时，上述结果提示了一般的自由能估计方法：可在某个受限的“试探概率分布” $P(x)$ 子空间内最小化 Gibbs 自由能。这些试探分布应足够简单，以便计算 $G[P]$；同时受限子空间又应包含能够较好地近似物理系统真实行为的分布。因此，每遇到新的物理系统，都需要寻找合适的受限子空间。

例 4.14. *考虑构型空间 $\mathcal{X}=\mathbb{R}$、能量为*

$$E(x)=\frac{1}{2}tx^2+\frac{1}{4}x^4, \tag{4.44}$$

且 $t\in\mathbb{R}$ 的系统。我们要计算其在逆温度 $\beta=1$ 时作为 t 的函数的自由能。略微滥用记号，我们关心

$$F(t)=-\log\left(\int dx\, e^{-E(x)}\right). \tag{4.45}$$

上述积分不能以闭合形式计算，因此求助于 Gibbs 变分原理。考虑以下试探概率分布族：

$$Q_a(x)=\frac{1}{\sqrt{2\pi a}}e^{-x^2/(2a)}. \tag{4.46}$$

[7]译注：以原文定义 $f_N(b)=-(1/N)\log Z_N(b)$ 代入式 (4.39)，得到 $\psi_N(t)=(1-t)f_N(\beta)-f_N(\beta(1-t))$，与式 (4.41) 不一致。若改用通常的物理自由能密度定义，也需同时处理第二项的温度因子；这里原式照录。对于允许零概率的分布，Boltzmann 表示还需允许无穷能量或限于其支集。

容易计算 $\beta = 1$ 时对应的 *Gibbs* 自由能：

$$G[Q_a] = \frac{1}{2}ta + \frac{3}{4}a^2 - \frac{1}{2}(1 + \log 2\pi a) \equiv G(a,t). \tag{4.47}$$

Gibbs 原理给出 $F(t) \le \min_a G(a,t)$。图 *4.5* 画出了 a 的最优值 $a_{\rm opt}(t) = \arg\min_a G(a,t)$ 及相应估计 $G_{\rm opt}(t) = G(a_{\rm opt}(t), t)$。

译注： 这里 $a > 0$；原文 “不能以闭合形式计算” 取决于允许使用哪些特殊函数，变分法在此用于近似说明。

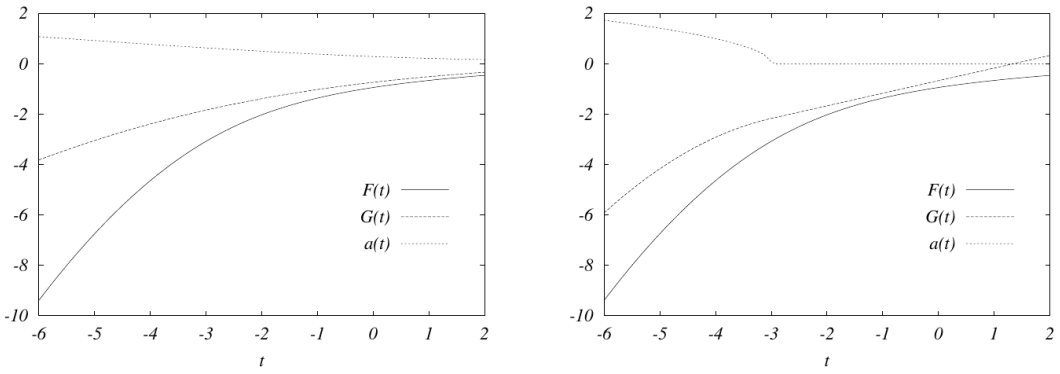


图 4.5: 模型 (4.44) 自由能的变分估计。左图使用试探分布 (4.46)，右图使用试探分布 (4.48)。取自 Part A 草稿第 88 页。

例 4.15. *考虑与上例相同的问题及试探分布族*

$$Q_a(x) = \frac{1}{\sqrt{2\pi}} e^{-(x-a)^2/2}. \tag{4.48}$$

留给读者作为习题：确定最优值 $a_{\rm opt}$ 及对应的 $F(t)$ 上界，参见图 4.5。注意 $t_{\rm cr} = -3$ 处发生的特殊现象：当 $t > t_{\rm cr}$ 时 $a_{\rm opt}(t) = 0$；当 $t \le t_{\rm cr}$ 时，$G[Q_a]$ 有两个简并局部极小值 $a = \pm a_{\rm opt}(t)$。

译注： 在临界点 $t = t_{\rm cr}$，这两个位置合并为 $a = 0$；原文不等号照录。

例 4.16. *考虑线性尺寸为 L 的 d 维晶格 $\mathsf{L} = [L]^d$ 上的 Ising 模型，参见第 2.5 节。能量函数为（注意归一化相对于第 2.5 节有所变化）*

$$E(\sigma) = -\sum_{(ij)} \sigma_i \sigma_j - B \sum_{i \in \mathsf{L}} \sigma_i. \tag{4.49}$$

为简单起见，假设周期边界条件：如果对某个 $l \in \{1, \dots, d\}$ 有 $i_l - j_l = \pm 1 \pmod L$，且对任意 $l' \ne l$ 有 $i_{l'} = j_{l'}$，则位置 $i = (i_1, \dots, i_d)$ 和 $j = (j_1, \dots, j_d)$ 是最近邻。式 (4.49) 中对 (ij) 的求和遍及 L 内所有最近邻对。

为获得逆温度 β 下自由能 $F(\beta)$ 的变分估计，在如下试探分布上计算 Gibbs 自由能：

$$Q_m(\sigma) = \prod_{i \in \mathsf{L}} q_m(\sigma_i), \tag{4.50}$$

其中 $q_m(+)=(1+m)/2$、$q_m(-)=(1-m)/2$，$m\in[-1,+1]$。注意，在 $Q_m(\sigma)$ 下，σ_i 是期望为 m 的独立同分布随机变量。

容易在该分布上计算 *Gibbs* 自由能。定义每格点 *Gibbs* 自由能为 $g(m;\beta,B)\equiv G[Q_m]/L^d$，则

$$g(m;\beta,B)=-\frac{1}{2}m^2-Bm+\frac{1}{\beta}H\!\left(\frac{1+m}{2}\right). \tag{4.51}$$

Gibbs 变分原理给出自由能密度的上界 $f(\beta)\le \inf_m g(m;\beta,h)$。注意，除一个加性常数外，表达式 (4.51) 与 *Curie–Weiss* 模型的解具有相同形式，参见式 *(2.79)*。因此有关对 m 优化的讨论可参阅第 *2.5.2* 节。这蕴含不等式

$$f_d(\beta,h)\le f_{\mathrm{CW}}(\beta,h)-\frac{1}{2}. \tag{4.52}$$

译注： 式 (4.51) 的熵项符号及 m^2 系数与前述能量、Gibbs 泛函不一致：通常周期方格晶格每格点 d 条无向键给出 $-dm^2$，概率熵项给出 $-H/\beta$（须明确二元熵的对数底）。式 (4.52) 也需在一致归一化下独立核验；原文的 B,h 记号变化照录。

式 (4.43) 中 Gibbs 自由能与 Kullback–Leibler 散度的关系，给出了 Gibbs 变分原理的简单概率解释。设想准备同一物理系统的大量副本 N 个，每个副本均由同一能量函数 $E(x)$ 描述。考虑 N 个副本的经验分布 $P(x)$。通常 $P(x)$ 接近 Boltzmann 分布 $P_\beta(x)$。Sanov 定理表明，“非典型”分布的概率随 N 指数级变小：

$$\mathbb{P}[P]\doteq \exp[-N(G[P]-F(\beta))]. \tag{4.53}$$

第 4.2 节的习题 4 对此作了说明。[8]

4.5 Monte Carlo 方法

Monte Carlo 方法是概率论、统计物理和组合优化共有的一种重要通用工具。在这些领域中，我们经常遇到这样的问题：从给定分布 $P(x)$ 中抽取一个构型 $x\in\mathcal{X}^N$（这里假设 $\mathcal{X}$ 为有限空间）。当 N 很大时，这可能十分困难：构型太多，典型构型指数级罕见，或者分布 $P(x)$ 由 Boltzmann 公式给定，而其归一化因子（配分函数）未知。

一种一般方法是构造保证收敛到所需分布 $P(x)$ 的 Markov 链，再在计算机上模拟它。当然，这里假设计算机能够使用某种随机源；实践中使用伪随机数发生器。若链模拟得足够久，最终构型的分布就会“接近” $P(x)$。具体而言，Markov 链由一组转移率 $w(x\to y)$ 定义，其中 $x,y\in\mathcal{X}^N$，并满足下列条件。

1. 链是*不可约的*，即对任意一对构型 x,y，都存在一条长度为 n、以非零概率连接 x 与 y 的路径 $(x_0,x_1,\dots,x_n)$。这意味着 $x_0=x$、$x_n=y$，且对 $i=0,\dots,n-1$ 有 $w(x_i\to x_{i+1})>0$。

2. 链是*非周期的*：对任意一对 x,y，都存在正整数 $n(x,y)$，使得对任意 $n\ge n(x,y)$，存在一条长度为 n、以非零概率连接 x 与 y 的路径。注意，对于不可约链，只要允许构型以非零概率保持不变，即 $w(x\to x)>0$，就很容易保证非周期性。

[8]译注：根据式 (4.43)，指数中的 KL 散度是 $\beta(G[P]-F(\beta))$，因此式 (4.53) 按通常定义似缺少因子 β；原文对习题编号的引用也需全章核对。

3. 分布 $P(x)$ 对转移概率 $w(x \to y)$ 是平稳的：

$$\sum_x P(x)w(x \to y) = P(y). \tag{4.54}$$

有时转移概率满足一个更强的条件，该条件蕴含平稳性。对每一对满足 $w(x \to y) > 0$ 或 $w(y \to x) > 0$ 的构型 x, y，均有

$$P(x)w(x \to y) = P(y)w(y \to x). \tag{4.55}$$

此条件称为可逆性或细致平衡。

译注： 这里的 w 实际用作离散时间转移概率，故对每个 x 还应满足 $w(x \to y) \geq 0$、$\sum_y w(x \to y) = 1$；原文沿用 “转移率” 的称呼。

通过设计并模拟这种过程来从 $P(x)$ 采样的策略，称为*动态 Monte Carlo 方法*或 *Markov 链 Monte Carlo 方法*（下文简称 Monte Carlo 方法）。其理论基础由两个经典定理给出，现将它们合述如下。

定理 4.17. *假设转移率 $w(x \to y)$ 满足上述三个假设。设 $X^0, X^1, \ldots, X^t, \ldots$ 是按转移率 $w(x \to y)$、初始条件 $X^0 = x_0$ 的 Markov 链分布的随机变量。设 $f : \mathcal{X}^N \to \mathbb{R}$ 为任意实值函数，则：*

1. X^t 的概率分布收敛于平稳分布：

$$\lim_{t\to\infty} \mathbb{P}[X^t = x] = P(x). \tag{4.56}$$

2. 时间平均收敛于平稳分布下的平均：

$$\lim_{t\to\infty} \frac{1}{t}\sum_{s=1}^{t} f(X^s) = \sum_x P(x)f(x) \qquad \text{几乎必然成立.} \tag{4.57}$$

本定理的证明可在任何一本 Markov 过程教科书中找到。这里用统计力学中经常使用的两个简单 Monte Carlo 算法来说明它，尽管这两个算法远非效率最高的算法。

例 4.18. *考虑由 N 个 Ising 自旋 $\sigma = (\sigma_1, \ldots, \sigma_N)$ 构成的系统，能量函数为 $E(\sigma)$，逆温度为 β。我们希望从 Boltzmann 分布 P_β 采样。随机更新的 Metropolis 算法定义如下。令 $\sigma^{(i)}$ 表示除位置 i 外均与 σ 一致的构型，其中 $\sigma_i^{(i)} = -\sigma_i$，并记 $\Delta E_i(\sigma) \equiv E(\sigma^{(i)}) - E(\sigma)$。每一步都按均匀概率分布随机选择整数 $i \in [N]$，再以概率*

$$w_i(\sigma) = \exp\{-\beta \max[\Delta E_i(\sigma), 0]\} \tag{4.58}$$

翻转自旋 σ_i。

用公式表示，转移概率为

$$w(\sigma \to \tau) = \frac{1}{N}\sum_{i=1}^{N} w_i(\sigma)\delta(\tau, \sigma^{(i)}) + \left[1 - \frac{1}{N}\sum_{i=1}^{N} w_i(\sigma)\right]\delta(\tau, \sigma), \tag{4.59}$$

其中 $\delta(\sigma,\tau)$ 在 $\sigma\equiv\tau$ 时为 *1*，否则为 *0*。容易检验，对于任意能量函数 $E(\sigma)$ 和逆温度 $\beta<1$，这一定义同时满足不可约性和平稳性条件。此外，该链满足细致平衡条件：

$$P_\beta(\sigma)w_i(\sigma)=P_\beta(\sigma^{(i)})w_i(\sigma^{(i)}). \tag{4.60}$$

是否满足非周期性则取决于能量。很容易构造不满足该条件的系统。例如取单个自旋 $N=1$，令 $E(\sigma)=0$：自旋每一步都翻转，因此不可能通过偶数步从 $\sigma=+1$ 转移到 $\sigma=-1$。（不过，只需如下修改算法，就容易消除这种异常。每一步以概率 $1-\varepsilon$ 选择一个位置 i，并像上面一样提出自旋翻转；以概率 ε 什么也不做，即进行空转移 $\sigma\to\sigma$。）

译注：源 PDF 可见文字确为 $\beta<1$，而不是 $\beta<\infty$。对于有限实能量和通常的 $0\le\beta<\infty$，此处的 Metropolis 转移具有所述不可约性和平稳性；若允许负 β，原式甚至可能大于 1。此处保留草稿条件，不将其当作已核准的参数范围。

习题 4.3. 改变翻转概率 (4.58)，可得到该链的变体。一种常用选择是热浴算法（也称 Glauber 动力学）：

$$w_i(\sigma)=\frac{1}{2}\left[1-\tanh\left(\frac{\beta\Delta E_i(\sigma)}{2}\right)\right]. \tag{4.61}$$

证明这些转移概率对应的链具有不可约性、非周期性和平稳性。

热浴算法受到关注的原因之一，是它很容易推广到构型空间具有 $\mathcal{X}^N$ 形式的任意系统。算法先选定一个变量指标 i，固定所有其他变量，再按条件分布给第 i 个变量赋一个新值。下面的伪代码给出更精确的描述。回顾：对于向量 $x\in\mathcal{X}^N$，用 $x_{\sim i}$ 表示删去第 i 个分量后得到的 $N-1$ 维向量。

热浴算法

输入：构型空间 $\mathcal{X}^N$ 上的概率分布 $P(x)$，以及迭代次数 r。

输出：序列 $x^{(0)},x^{(1)},\dots,x^{(r)}$。

1. 在 $\mathcal{X}^N$ 中均匀随机生成 $x^{(0)}$。
2. 对 $t=1,\dots,r$：
   (a) 均匀随机抽取整数 $i\in\{1,\dots,N\}$。
   (b) 对每个 $z\in\mathcal{X}$，计算
   $$P(X_i=z\mid X_{\sim i}=x_{\sim i}^{(t-1)}y)=\frac{P(X_i=z,X_{\sim i}=x_{\sim i}^{(t-1)})}{\sum_{z'\in\mathcal{X}}P(X_i=z',X_{\sim i}=x_{\sim i}^{(t-1)})}. \tag{4.62}$$
   (c) 对每个 $j\ne i$ 令 $x_j^{(t)}=x_j^{(t-1)}$，并令 $x_i^{(t)}=z$，其中 z 按分布 $P(X_i=z\mid X_{\sim i}=x_{\sim i}^{(t-1)}y)$ 抽取。

译注：原式 (4.62) 左侧及下一步的条件中均多出未定义的 y；右侧没有该符号。此处照录，算法的通常含义是以 $X_{\sim i}=x_{\sim i}^{(t-1)}$ 为条件。

强调一下：此算法只要求将概率 $P(x)$ 计算到一个乘法常数。例如，若 $P(x)$ 由 Boltzmann 定律给定，参见第 2.1 节，只要能计算构型的能量 $E(x)$ 即可，而不必计算配分函数 $Z(\beta)$。

这是一种定义具有所需性质的 Markov 链的十分一般的方法。证明留作习题。

习题 4.4. 为简单起见，假设对所有 x 均有 $P(x)>0$。证明热浴算法具有不可约性、非周期性和平稳性。

定理 4.17 说明，Monte Carlo 方法确实是从给定概率分布采样的一种可行方法。然而，它没有给出计算效率方面的任何信息。为讨论这一问题，方便起见，假设模拟 Markov 链的一步 $X^t \to X^{t+1}$ 的时间开销为一个单位。只要抽取新构型只需固定的有限次数计算，并只更新有限个、数目不依赖于 N 的变量，这一假设就是合理的。上述两个例子正是如此，这里只讨论这种简单情形。[9]

于是，计算效率问题归结为：应模拟 Markov 链多少步？如此一般的问题当然没有唯一答案。我们只介绍两个重要的衡量指标。第一个涉及如下问题：为了产生一个近似服从 $P(x)$ 的构型 x，应模拟多少步？为准确说明 "近似" 的含义，需要引入 $\mathcal{X}^N$ 上分布 $P_1(\cdot)$、$P_2(\cdot)$ 之间的距离。一种常用定义是全变差距离：

$$\|P_1 - P_2\| = \frac{1}{2}\sum_{x\in\mathcal{X}^N} |P_1(x) - P_2(x)|. \tag{4.63}$$

现在考虑关于平稳分布 $P(x)$ 满足上述三个假设的 Markov 链，以 $P_t(x \mid x_0)$ 表示初始条件为 $X^0 = x_0$ 时 X^t 的分布。令 $d_{x_0}(t) = \|P_t(\cdot \mid x_0) - P(\cdot)\|$ 表示到平稳分布的距离。混合时间（或变差阈值时间）定义为

$$\tau_{\rm eq}(\varepsilon) = \min\{t>0 : \sup_{x_0} d_{x_0}(t) \le \varepsilon\}. \tag{4.64}$$

本书常将这一量（或某个与其相近的量）非正式地称为平衡时间。数值 ε 可以任意选择，改变 ε 通常只使 $\tau_{\rm eq}(\varepsilon)$ 发生简单的乘法变化。因此，有时采用 $\varepsilon = 1/e$ 的约定。

人们往往关心计算某个可观测量 $\mathcal{O}(x)$ 的期望，而不是生成一个服从指定分布的构型。原则上，按式 (4.57)，对 Markov 链的许多步取平均即可做到。于是自然提出如下问题。假设初始条件 X^0 服从平稳分布 $P(x)$。这可以通过在预先的平衡阶段模拟链 $\tau_{\rm eq}(\varepsilon)$ 步来实现。用 $\langle\cdot\rangle$ 表示在这一初始条件下对 Markov 链取期望。为了在指定精度内得到期望值，需要对多少步取平均？换言之，我们用

$$\overline{\mathcal{O}}_T \equiv \frac{1}{T}\sum_{t=0}^{T-1} \mathcal{O}(X^t) \tag{4.65}$$

估计 $\sum_x P(x)\mathcal{O}(x) \equiv \mathbb{E}_P\mathcal{O}$。显然 $\langle\overline{\mathcal{O}}_T\rangle = \sum_x P(x)\mathcal{O}(x)$。计算这一估计量的方差：

$$\mathrm{Var}(\overline{\mathcal{O}}_T) = \frac{1}{T^2}\sum_{s,t=0}^{T-1}\langle\mathcal{O}_s;\mathcal{O}_t\rangle = \frac{1}{T^2}\sum_{t=0}^{T-1}(T-t)\langle\mathcal{O}_0;\mathcal{O}_t\rangle, \tag{4.66}$$

其中用了记号 $\mathcal{O}_t \equiv \mathcal{O}(X^t)$。引入自相关函数 $C_{\mathcal{O}}(t-s) \equiv \langle\mathcal{O}_s;\mathcal{O}_t\rangle/\langle\mathcal{O}_0;\mathcal{O}_0\rangle$，于是 $\mathrm{Var}(\overline{\mathcal{O}}_T) = \langle\mathcal{O}_0;\mathcal{O}_0\rangle T^{-2}\sum_{t=0}^{T-1}(T-t)C_{\mathcal{O}}(t)$。有限状态空间上 Markov 链的一般结果表明，当 $t\to\infty$ 时 $C_{\mathcal{O}}(t)$ 指数衰减。因此，对于大的 T 有

$$\mathrm{Var}(\overline{\mathcal{O}}_T) = \frac{\tau^{\mathcal{O}}_{\rm int}}{T}[\mathbb{E}_P\mathcal{O}^2 - (\mathbb{E}_P\mathcal{O})^2] + O(T^{-2}). \tag{4.67}$$

[9]译注：任意能量函数或任意联合分布未必允许常数时间的单点条件概率或能量差计算；单位时间假设须另行验证，不能仅由 "每次更新一个变量" 推出。

积分自相关时间 $\tau_{\mathrm{int}}^{\mathcal{O}}$ 为

$$\tau_{\mathrm{int}}^{\mathcal{O}} \equiv \sum_{t=0}^{\infty} C_{\mathcal{O}}(t), \tag{4.68}$$

它为估计 Monte Carlo 模拟需要运行多长时间才能达到指定精度提供了参考。式 (4.67) 可以解释为：每隔 $\tau_{\mathrm{int}}^{\mathcal{O}}$ 次迭代，就得到一个对 $\mathbb{E}_P\mathcal{O}$ 的统计独立估计。[10]

例 4.19. *考虑第 2.5.2 节中的 Curie–Weiss 模型，逆温度为 β，并用例 2 中的热浴算法从 Boltzmann 分布采样。在图?? 中，我们展示了 $N = 150$ 个自旋的模型在 $\beta = 0.8, 1.0, 1.2$ 下三次不同模拟期间总磁化强度 $m(\sigma)$ 的演化。所有情况下，都通过从均匀概率分布中抽取随机构型来初始化 Markov 链。*

最低温度 $\beta = 1.2$ 时出现了显著现象。尽管总磁化强度的 Boltzmann 平均值为零，即 $\langle m(\sigma)\rangle = 0$，磁化强度的符号却在极长的时间尺度上保持不变。显然平衡时间至少与这些时间尺度一样长。数量级估计为 $\tau_{\mathrm{eq}} > 10^5$。此外，这一平衡时间在 N 较大时随 N 指数发散。因此，低温下用当前算法从 Boltzmann 分布采样变得极其困难。

译注： 草稿写 “例 2” 且图号为??，本地 Part A 未见对应的磁化强度轨迹图。保留这两个未完成的原文引用，不将现有图 4.5 充作此图；算法定义参见习题 4.3 及其后伪代码。

4.6 模拟退火

如第 3.5 节所述，任意优化问题都可 “嵌入” 统计力学问题。思路是把代价函数 $E(x)$、$x \in \mathcal{X}^N$ 解释为统计力学系统的能量，并考虑 Boltzmann 分布 $p_\beta(x) = \exp[-\beta E(x)]/Z$。在低温极限 $\beta \to \infty$ 下，分布集中到 $E(x)$ 的极小值上，从而恢复原来的优化问题。

既然 Monte Carlo 方法提供了从 Boltzmann 分布采样的一般技术，我们就会问：能否在 $\beta \to \infty$ 极限下把它用作优化技术？一种简单的做法是一开始就取 $\beta = \infty$。这种策略在统计物理中通常称为淬火，在组合优化中称为贪心搜索，而且往往会失败。事实上，考虑平稳性条件 (4.54)，用 Boltzmann 公式将其重写为

$$\sum_{x} e^{-\beta[E(x)-E(y)]} w(x \to y) = 1. \tag{4.69}$$

由于左侧各项均为正，每项都不能大于 1。这意味着 $0 \le w(x \to y) \le \exp\{-\beta[E(y) - E(x)]\}$。因此，对于任意满足 $E(y) > E(x)$ 的一对构型 x, y，当 $\beta \to \infty$ 时有 $w(x \to y) \to 0$。换言之，沿零温 Monte Carlo 算法的轨迹，能量总是非增的。因此，对应的 Markov 链不再不可约，尽管它在任意 $\beta < \infty$ 时都不可约；也就无法保证收敛于平衡分布，即无法保证找到 $E(x)$ 的全局最小值。[11]

[10] 译注：此段按原文保留。有限步平衡只保证与平稳分布的距离不超过 ε，一般不能得到严格平稳初态。另在平稳标量过程中，式 (4.66) 的第二个等号漏计正、负时间差：正确合并为 $T^{-2}[T\gamma(0) + 2\sum_{t=1}^{T-1}(T-t)\gamma(t)]$，其中 $\gamma(t) = \langle \mathcal{O}_0; \mathcal{O}_t\rangle$。因此若沿用原文 (4.68) 的定义，大 T 方差的首项系数为 $2\tau_{\mathrm{int}}^{\mathcal{O}} - 1$，而不是 $\tau_{\mathrm{int}}^{\mathcal{O}}$。相关函数还需 $\gamma(0) > 0$ 才有上述归一化定义；方差对应的有效样本数也不等同于严格独立采样。

[11] 译注：求和各项一般为非负。“零温链不再不可约” 在存在不同能量构型、且零温转移极限存在的通常情形成立；若能量为常数，则不能从能量非增单独推出不可约性失效。有限温度的不可约性也取决于所选择的转移机制。

另一种简单做法是将 β 设为较大但有限的值。虽然 Boltzmann 分布也给接近最优的构型赋予一定权重，算法仍会不时访问概率最大的最优构型。β 应有多大？最优构型出现之前应等待多久？不失一般性，假设代价函数的最小值（基态能量）为零，即 $E_0 = 0$。一个值得考察的量是逆温度 β 的 Boltzmann 分布下 $E(x) = 0$ 的概率。能量的对数矩母函数很容易计算：

$$\psi_N(t) = \frac{1}{N} \log \left[\sum_x p_\beta(x) e^{tE(x)} \right] = \frac{1}{N} \log \left[\frac{\sum_x e^{-(\beta - t)E(x)}}{\sum_x e^{-\beta E(x)}} \right]. \tag{4.70}$$

即 $\psi_N(t) = \phi_N(\beta - t) - \phi_N(\beta)$，其中 $\phi_N(\beta)$ 是逆温度 β 下的自由熵密度。显然

$$\begin{aligned} p_\beta[E(x) = 0] &= \exp[N\psi_N(-\infty)] \\ &= \exp\{N[\phi_N(\infty) - \phi_N(\beta)]\}, \end{aligned}$$

访问最优构型之前的平均等待时间为 $1/p_\beta[E(x) = 0] = \exp[-N\psi_N(-\infty)]$。[12]

习题 4.5. 假设代价函数取整数值 $E = 0, 1, 2, \ldots$，以 $\mathcal{X}_E$ 表示满足 $E(x) = E$ 的构型 x 的集合。希望 *Monte Carlo* 轨迹在最优解上花费比例为 $1 - \varepsilon$ 的时间。证明应选择满足下式的温度：

$$\beta = \log \left(\frac{|\mathcal{X}_1|}{\varepsilon |\mathcal{X}_0|} \right) + \Theta(\varepsilon). \tag{4.71}$$

译注： 这是对逆温度的表述，且原文没有给出 ε 渐近极限、$\mathcal{X}_1 \neq \varnothing$ 及更高能级简并度等条件。固定有限系统且 $|\mathcal{X}_0|, |\mathcal{X}_1| > 0$ 时，小 ε 展开给出相应对数首项与 $O(\varepsilon)$ 修正；若第一激发能不为 1，该首项也会改变。一般不能无条件断言修正恰为 $\Theta(\varepsilon)$。

第 2.4 节曾说明，许多统计力学模型的自由熵密度具有有限的热力学极限

$$\phi(\beta) = \lim_{N \to \infty} \phi_N(\beta).$$

后续章节将表明，若干有趣的优化问题也具有这一性质。这意味着 $p_\beta[E(x) = 0]$ 在 $N \to \infty$ 极限下趋于零。为了以不可忽略的概率找到优化问题的解，必须使 β 随 N 缩放，并在 $N \to \infty$ 时令 $\beta \to \infty$。另一方面，令 $\beta \to \infty$ 又会遇到上述可约性问题。尽管 Markov 链在形式上不可约，其平衡时间却会在 $\beta \to \infty$ 时发散。[13]

模拟退火的思路是让 β 随时间变化。更具体地说，先确定退火日程

$$\{(\beta_1, n_1); (\beta_2, n_2); \ldots; (\beta_L, n_L)\},$$

其中逆温度 $\beta_i \in [0, \infty]$，整数 $n_i > 0$。算法从构型 x_0 初始化，先在温度 β_1 下执行 n_1 个 Monte Carlo 步，再在温度 β_2 下执行 n_2 步，依此类推，最后在温度 β_L 下执行 n_L 步。每个阶段 i $(i = 1, \ldots, L - 1)$ 的最终构型用作下一阶段的初始构型。在数学上，这种过程是随时间变化的 *Markov* 链。[14]

[12] 译注：平稳概率的倒数给出从目标集合按平稳条件分布出发的平均回返时间（按通常回返时间定义）；一般初态到目标集合的平均首次到达时间不能仅由平稳概率确定。原文未区分这些等待时间。

[13] 译注：仅有自由熵密度存在有限极限，不足以推出基态概率趋零；还需比较基态熵密度与有限温度自由熵密度。常数能量给出直接例外。平衡时间的发散同样依赖能量景观及转移规则。

[14] 译注：这里沿用原文将 β_i 称为温度的措辞；按照定义，它实际是逆温度。

关于模拟退火算法，通常的直观认识是：随时间改变温度应有助于避免上述两个问题。一般取 β_i 为递增序列。初期较小的 β 应有助于在整个构型空间 $\mathcal{X}^N$ 上达到平衡。随着温度降低，概率分布集中到该空间中能量最低的区域。最后，在后期，较大的 β 迫使系统修正少数错误细节并找到解。当然，这一图景非常简化。下一章将通过考察模拟退火在各种问题上的应用，尝试将其细化。

4.7 附录：物理学家处理 Sanov 定理的方法

下面说明，如何用统计物理中常用的 “场论” 方法得到 Sanov 定理中的公式。该定理本来很容易证明；本节的目的与其说是给出证明，不如说是通过一个简单例子展示一种物理学中十分常见且可能很有力的方法。这里不追求严格推导。

序列 $x_1,\dots,x_N$ 的类型等于 $q(x)$ 的概率可写成

$$\begin{aligned}\mathbb{P}[q(x)] &= \mathbb{E}\left\{\prod_{x\in\mathcal{X}} \mathbf{1}\left(q(x)=\frac{1}{N}\sum_{i=1}^{N}\delta_{x,x_i}\right)\right\}\\ &= \sum_{x_1\cdots x_N} p(x_1)\cdots p(x_N)\,\mathbf{1}\left(q(x)=\frac{1}{N}\sum_{i=1}^{N}\delta_{x,x_i}\right). \end{aligned} \tag{4.72}$$

译注： 第二行按原式照录，但缺少第一行对 $x\in\mathcal{X}$ 的乘积，且 x 成为未约束变量。表示整个经验分布恰为 q 时，应对全部符号同时施加约束。

场论中一种典型做法，是引入一些辅助变量来实施约束 $q(x)=N^{-1}\sum_{i=1}^{N}\delta_{x,x_i}$。对于每个 $x\in\mathcal{X}$，引入变量 $\lambda(x)$，并使用以下形式的约束 “积分表示”：

$$\mathbf{1}\left(q(x)=\frac{1}{N}\sum_{i=1}^{N}\delta_{x,x_i}\right)=\int_0^{2\pi}\frac{d\lambda(x)}{2\pi}\exp\left[i\lambda(x)\left(Nq(x)-\sum_{i=1}^{N}\delta_{x,x_i}\right)\right]. \tag{4.73}$$

舍去与 q 无关的因子，得到

$$\mathbb{P}[q(x)] = C\int\prod_{x\in\mathcal{X}} d\lambda(x)\,\exp\{NS[\lambda]\},$$

其中 C 为归一化常数，作用量 S 为

$$S[\lambda]=i\sum_x\lambda(x)q(x)+\log\left[\sum_x p(x)e^{-i\lambda(x)}\right]. \tag{4.74}$$

当 N 很大时，可以用鞍点方法计算式 (4.74) 中的积分。对所有 $x\in\mathcal{X}$ 解驻点方程 $\partial S/\partial\lambda(x)=0$，即可找到鞍点 $\lambda(x)=\lambda^*(x)$。得到一族解 $-i\lambda(x)=C+\log(q(x)/p(x))$，其中 C 任意。选择 C 的自由度来自这样一个事实：对于任意构型 $x_1,\dots,x_N$，都有 $\sum_x(\sum_i\delta_{x,x_i})=N$，因而其中一个约束实际上是多余的。该自由度可任意固定；无论如何选择，鞍点处的作用量均为

$$S[\lambda^*]=S_0-\sum_x q(x)\log\frac{q(x)}{p(x)}, \tag{4.75}$$

其中 S_0 是与 q 无关的常数。于是得到 $\mathbb{P}[q(x)]\doteq\exp[-ND(q\|p)]$。[15]

[15]译注：原文把积分指向式 (4.74)，该编号实际对应作用量，积分在其前一行。傅里叶约束表示在 $Nq(x)$ 为整数、即 q 为可实现类型时适用；零概率、零频数与复鞍点的积分路径变形还需额外处理。本节按照作者说明只给形式推导，不把它升格为严格证明。

从未接触过这种推理的读者可能会问，为何要采用如此迂回的方法。实际上，这是统计物理中十分常用的形式体系；类似方法也以“场论”之名用于连续空间 $\mathcal{X}$（中间步骤通常隐含某种离散化，而连续极限的正确定义往往并不明显）。特别是，对优化问题或信息论的统计物理方法感兴趣的读者，经常会在研究论文中遇到这种形式体系。其优点之一，是能够为种类繁多的问题提供形式解。待计算的量被写成式 (4.74) 那样的积分形式。在具有“平均场”结构的问题中，积分空间的维数不依赖于 N，因此可以用鞍点方法得到它在大 N 下的主导指数行为。想练习这种方法的读者，可以尝试以同样方式“推导”本章的各个定理和推论。

注释

大偏差理论可参阅 Dembo 和 Zeitouni 的著作（Dembo and Zeitouni, 1998），它在统计物理中的应用可参阅 Ellis 的著作（Ellis, 1985）。

离散状态空间上的 Markov 链可参阅 Norris（Norris, 1997）。Krauth 的讲义（Krauth, 1998）和 Sokal 的讲义（Sokal, 1996） 对统计物理中的 Monte Carlo 方法作了很好的介绍。

模拟退火由 Kirkpatrick、Gelatt 和 Vecchi 于 1983 年提出（Kirkpatrick, C. D. Gelatt and Vecchi, 1983）。它是一种完全“通用”的优化算法：定义它时无需涉及任何特定问题。也正因如此，它常常忽略那些可能有助于求解问题本身的重要结构。

第五章　随机能量模型

随机能量模型（random energy model，REM）可能是会出现相变的最简单的无序系统统计物理模型。它并不试图真实描述任何物理系统，却提供了一个可操作的例子，供人们详细研究各种概念和方法。此外，由于模型简单，同一种数学结构会出现在许多不同情境中，后两章关于信息论和组合优化的例子就说明了这一点。第 5.1 节定义模型，第 5.2 节研究其热力学性质。这两节建立的简单方法在许多问题中都很有用。第 5.3 节更详细地研究低温相，相应计算也更加复杂。第 5.4 节介绍所谓的退火近似，它将在更复杂的模型中发挥作用。

5.1　模型定义

统计力学模型由构型集合及其上的能量函数定义。在 REM 中，有 $M = 2^N$ 个构型（就像由 N 个 Ising 自旋构成的系统），以指标 $i, j, \ldots \in \{1, \ldots, 2^N\}$ 表示。REM 是无序模型：能量不是确定性函数，而是随机过程。该过程的一个具体实现通常称为一个样本（或实例）。REM 对这一过程采用最简单的选择：能量 $\{E_i\}$ 是独立同分布随机变量（构型的能量也称为一个能级）。为明确起见，这里只考虑均值为零、方差为 $N/2$ 的 Gaussian 分布，其他分布也可研究。[1]于是，状态 i 的能量 E_i 的概率密度函数为

$$P(E) = \frac{1}{\sqrt{\pi N}} e^{-E^2/N}. \tag{5.1}$$

给定一个 REM 实例，即从密度函数 (5.1) 抽取的 2^N 个实数 E_j，按通常方式给每个构型 i 赋予 Boltzmann 概率 p_i：

$$p_j = \frac{1}{Z} \exp(-\beta E_j), \tag{5.2}$$

其中 $\beta = 1/T$ 为逆温度，归一化因子 Z（配分函数）为

$$Z = \sum_{j=1}^{2^N} \exp(-\beta E_j). \tag{5.3}$$

注意，Z 依赖温度 β、“样本规模” N，以及能级 $E_1, \ldots, E_M$ 的具体实现。上式略去了所有这些依赖关系。

与一切无序系统一样，REM 中存在两层概率，不要将它们混淆。我们关心的是一个概率分布，即 Boltzmann 分布 (5.2) 的性质；但由于能级为随机变量，这个分布本身也是随机对象。

[1]应适当选择分布随 N 的标度，使热力学势具有广延性。

在物理上，能量函数的某个具体实现对应某种物质的给定样本，其微观细节无法在实验中控制。金属合金就是如此：我们只能控制各组分的比例，而每类原子的精确位置用随机变量描述。下文用 $\mathbb{E}(\cdot)$ 表示对样本实现取期望。给定一个样本，Boltzmann 定律 (5.2) 按各构型的能量给出占据它们的概率。对 Boltzmann 分布的平均记为 $\langle\cdot\rangle$。实验处理的是给定无序材料的一个（或少数几个）样本，因此我们可能希望计算这个特定样本的各个热力学势（自由能 F_N、内能 U_N 或熵 S_N）。这是一项极其困难的任务。不过我们将看到，当 $N\to\infty$ 时，强度型热力学势的概率分布集中在其期望值附近：对于任意势 X（$X=F,S,U,\dots$）和任意容许偏差 $\theta>0$，

$$\lim_{N\to\infty}\mathbb{P}\left[\left|\frac{X_N}{N}-\mathbb{E}\left(\frac{X_N}{N}\right)\right|\geq\theta\right]=0. \tag{5.4}$$

此时称量 X 具有自平均性。这一关键性质可通俗地概括为：几乎所有大样本的“行为”相同。[2]收敛通常随 N 指数级地快（例如 REM 就是如此）；这意味着即使规模适中，期望值 $\mathbb{E}X_N$ 已能很好地描述系统。[3]

5.2 REM 的热力学

本节计算 REM 在热力学极限 $N\to\infty$ 下的热力学势。策略是先估计第 2.4 节引入的微正则熵密度，再据此在大 N 下以指数精度计算配分函数 Z。

5.2.1 直接计算熵

考虑能量区间 $I=[N\varepsilon,N(\varepsilon+\delta)]$，用 $\mathcal{N}(\varepsilon,\varepsilon+\delta)$ 表示满足 $E_i\in I$ 的构型 i 的数目。每个能级 E_i 独立地以概率

$$P_I=\sqrt{\frac{N}{\pi}}\int_{\varepsilon}^{\varepsilon+\delta}e^{-Nx^2/2}\,dx \tag{5.5}$$

落入 I。因此 $\mathcal{N}(\varepsilon,\varepsilon+\delta)$ 为二项随机变量，其期望和方差为

$$\mathbb{E}\mathcal{N}(\varepsilon,\varepsilon+\delta)=2^NP_I,\qquad\qquad \operatorname{Var}\mathcal{N}(\varepsilon,\varepsilon+\delta)=2^NP_I(1-P_I). \tag{5.6}$$

由于区间 I 随 N 的标度选择适当，概率 P_I 对 N 具有指数依赖。因此，在指数精度下有

$$\mathbb{E}\mathcal{N}(\varepsilon,\varepsilon+\delta)\doteq\exp\left\{N\max_{x\in[\varepsilon,\varepsilon+\delta]}s_a(x)\right\}, \tag{5.7}$$

$$\frac{\operatorname{Var}\mathcal{N}(\varepsilon,\varepsilon+\delta)}{[\mathbb{E}\mathcal{N}(\varepsilon,\varepsilon+\delta)]^2}\doteq\exp\left\{-N\max_{x\in[\varepsilon,\varepsilon+\delta]}s_a(x)\right\}, \tag{5.8}$$

其中 $s_a(x)\equiv\log 2-x^2$。注意，$s_a(x)\geq 0$ 当且仅当 $x\in[-\varepsilon_*,\varepsilon_*]$，这里 $\varepsilon_*=\sqrt{\log 2}$。**译注：**源 PDF 的式 (5.5) 确为 $e^{-Nx^2/2}$，但与密度 (5.1) 换元所得的 e^{-Nx^2} 及后文 s_a 不一致；此处原式保留。

这些等式的直观含义如下：当 ε 在区间 $[-\varepsilon_*,\varepsilon_*]$ 之外时，典型能级密度随 N 指数级地小；对于一般样本，在 $E_i\approx N\varepsilon$ 附近没有构型。相反，当 $\varepsilon\in(-\varepsilon_*,\varepsilon_*)$ 时，能级密度指数级地大，而密度涨落很小。图 5.1 用一个小型数值实验说明了这一结果。下面更正式地陈述它。

[2]这就是化学组成相同的不同合金样本具有相同热力学性质的原因。

[3]译注：β 是逆温度，原文此处也以“温度”泛指它。式 (5.4) 为依概率集中，不应仅从该式直接加强为几乎必然收敛。

命题 5.1. 定义熵函数

$$s(\varepsilon) = \begin{cases} s_a(\varepsilon) = \log 2 - \varepsilon^2, & |\varepsilon| \le \varepsilon_*, \\ -\infty, & |\varepsilon| > \varepsilon_*. \end{cases} \tag{5.9}$$

则对于任意一对 ε, δ，以概率 1 有

$$\lim_{N\to\infty} \frac{1}{N} \log \mathcal{N}(\varepsilon, \varepsilon+\delta) = \sup_{x\in[\varepsilon,\varepsilon+\delta]} s(x). \tag{5.10}$$

证明. 证明只需简单利用式 (5.7)、(5.8) 给出的区间 I 中能级数的前两个矩。

先假设区间 $[\varepsilon, \varepsilon+\delta]$ 与 $[-\varepsilon_*, \varepsilon_*]$ 不相交。则 $\mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta) \doteq e^{-AN}$，其中

$$A = -\sup_{x\in[\varepsilon,\varepsilon+\delta]} s_a(x) > 0.$$

由于 $\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 是整数，有简单的不等式

$$\mathbb{P}[\mathcal{N}(\varepsilon, \varepsilon+\delta) > 0] \le \mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta) \doteq e^{-AN}. \tag{5.11}$$

换言之，在 $[-\varepsilon_*, \varepsilon_*]$ 外任意固定区间中存在能级的概率随 N 指数级地小。形如 (5.11) 的不等式称为 *Markov* 不等式，其一般策略有时称为一阶矩方法。附录??? 对这一方法作了一般介绍。

再假设 $[\varepsilon, \varepsilon+\delta]$ 与 $[-\varepsilon_*, \varepsilon_*]$ 的交集是具有有限长度的区间。此时 $\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 紧密集中在其期望 $\mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 附近，可用 Chebyshev 不等式证明。对任意固定 $C > 0$，有

$$\mathbb{P}\left\{ \left| \frac{\mathcal{N}(\varepsilon, \varepsilon+\delta)}{\mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta)} - 1 \right| > C \right\} \le \frac{\operatorname{Var}\mathcal{N}(\varepsilon, \varepsilon+\delta)^2}{C^2[\mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta)]^2} \doteq e^{-BN}, \tag{5.12}$$

其中 $B = \sup_{x\in[\varepsilon,\varepsilon+\delta]} s_a(x) > 0$。上述推理的一个小变体常称为二阶矩方法，将在附录???? 中进一步讨论。

最后，直接应用 Borel–Cantelli 引理，即可由上述估计得到结论 (5.10)。 □

译注： 式 (5.12) 的分子按原文保留额外的平方，通常 Chebyshev 上界应为 $\operatorname{Var}\mathcal{N}$，而不是对 $\mathcal{N}$ 再平方。区间应取 $\delta > 0$，第二种情形需要交集具有正长度。原命题未处理仅在 $\pm\varepsilon_*$ 接触的区间：例如 $[\varepsilon_*, \varepsilon_*+\delta]$ 的右端表达式为 0，但其中能级数以高概率为 0，不能据所给证明推出所写几乎必然极限。原命题和两个未定附录引用均保留。

习题 5.1. 大偏差：令 $\mathcal{N}_{\text{out}}(\delta)$ 为满足 $|E_j| > N(\varepsilon_* + \delta)$ 的构型 j 的总数，其中 $\delta > 0$。用 *Markov* 不等式证明，存在这类构型的样本所占比例指数级地小。

命题 5.1 不仅是一个有趣的数学结论，也给出良好的定量估计。如图 5.1 所示，$N = 20$ 时数值实验结果已很接近渐近预测。注意，对于 $(-\varepsilon_*, \varepsilon_*)$ 中的能量，大部分偏差来自舍去了 $\mathbb{E}\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 中的次指数因子。⋆容易证明，这会对渐近行为 (5.10) 产生 $\Theta(\log N/N)$ 量级的修正；而 $\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 围绕其平均值涨落的贡献随 N 指数级地小。[4]

[4]译注：次指数修正的具体阶数需结合固定区间、端点或驻点位置及非退化条件理解；此处未将原文的 Θ 表述认证为所有区间的一致双侧估计。

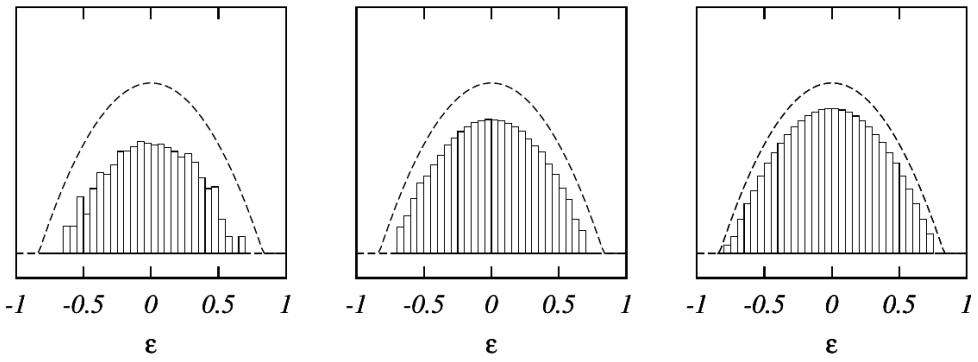


图 5.1: 随机能量模型三个样本的能级直方图，规模从左到右为 $N = 10, 15, 20$。纵轴为 $N^{-1}\log\mathcal{N}(\varepsilon, \varepsilon+\delta)$，横轴为 ε，取 $\delta = 0.05$。虚线为式 (5.9) 的 $N \to \infty$ 解析预测。取自 Part B PDF 第 4 页（原印刷页 96）。

5.2.2 热力学与相变

由上述微正则熵密度的结果，现计算配分函数 $Z_N(\beta) = \sum_{i=1}^{2^N} \exp(-\beta E_i)$。我们特别关心强度型热力学势，例如自由熵密度 $\phi(\beta) = \lim_{N\to\infty} N^{-1}\log Z_N(\beta)$。先采用第 2.4 节概述的一般方法，给出一个快速而不严格的论证：以步长 δ 离散化能量轴，并用式 (5.10) 计数每个区间内的能级。最终取 $\delta \to 0$ 极限（在 $N \to \infty$ 极限之后），预期在主导指数阶得到

$$Z_N(\beta) \doteq \int_{-\varepsilon_*}^{\varepsilon_*} d\varepsilon\, \exp[N(s_a(\varepsilon) - \beta\varepsilon)]. \tag{5.13}$$

可以类似于命题 2.6 中的一般等价关系，严格陈述这一结果。[5]得到自由熵密度

$$\phi(\beta) = \max_{\varepsilon\in[-\varepsilon_*,\varepsilon_*]} [s_a(\varepsilon) - \beta\varepsilon]. \tag{5.14}$$

注意，虽然 REM 的每个样本都是一个新的统计物理系统，可能具有各自的热力学势，我们却发现几乎所有样本具有相同的自由熵密度 (5.14)，从而具有相同的能量、熵和自由能密度。更精确地说，对于任意固定容许偏差 $\theta > 0$，当 $N \to \infty$ 时，不等式 $|N^{-1}\log Z_N(\beta) - \phi(\beta)| < \theta$ 成立的概率趋于 1。

下面讨论结果 (5.14) 的物理含义。右侧的优化问题可通过图 5.2 所示的几何构造求解：寻找曲线 $s_a(\varepsilon) = \log 2 - \varepsilon^2$ 上斜率为 $\beta \geq 0$ 的切线。令 $\varepsilon_a(\beta) = -\beta/2$ 为切点横坐标。若 $\varepsilon_a(\beta) \in [-\varepsilon_*, \varepsilon_*]$，式 (5.14) 的最大值在 $\varepsilon_a(\beta)$ 达到；否则 $\varepsilon_a(\beta) < -\varepsilon_*$（因为 $\beta \geq 0$），最大值在 $-\varepsilon_*$ 达到。因此：

命题 5.2. *REM 的自由能 $f(\beta) = -\phi(\beta)/\beta$ 为*

$$f(\beta) = \begin{cases} -\frac{1}{4}\beta - \log 2/\beta, & \beta \leq \beta_c, \\ -\sqrt{\log 2}, & \beta > \beta_c, \end{cases} \qquad \beta_c = 2\sqrt{\log 2}. \tag{5.15}$$

[5]不过，这里的工作更困难，因为能级密度 $\mathcal{N}(\varepsilon, \varepsilon+\delta)$ 是随机函数，必须控制其涨落。

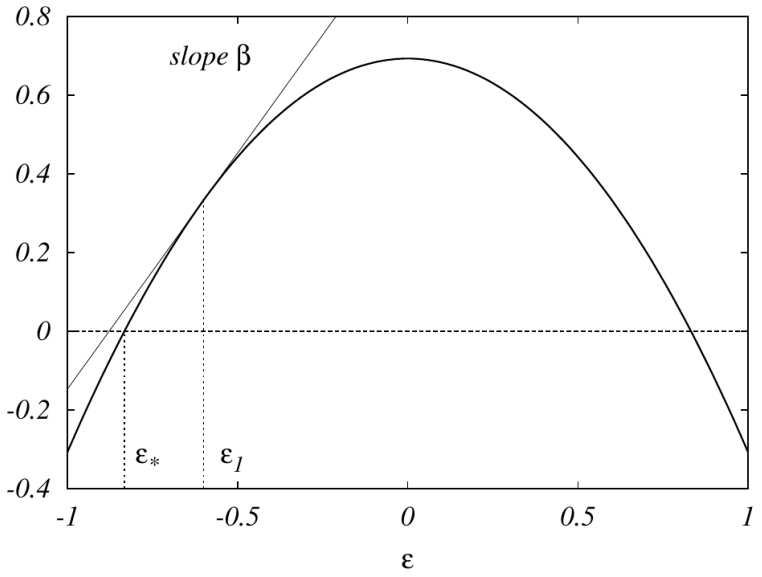


图 5.2: REM 的 “退火” 熵密度 $s_a(\varepsilon)$ 随能量密度 ε 的变化，参见式 (5.14)。当满足 $ds_a/d\varepsilon = \beta$ 的点位于 $[-\varepsilon_*, \varepsilon_*]$ 内时，正则熵密度 $s(\beta)$ 为该点的纵坐标（例如图中 $\varepsilon = \varepsilon_1$ 的情形）；否则 $s(\beta) = 0$。这导致 $\beta_c = 2\sqrt{\log 2}$ 处的相变。在 “退火” 近似中，由于稀有样本对配分函数的贡献，相变未被识别，并且会涉及曲线的 $s_a(\varepsilon) < 0$ 部分，参见第 5.4 节。取自 Part B PDF 第 6 页（原印刷页 98）。

这表明，在临界逆温度 $\beta_c = 1/T_c = 2\sqrt{\log 2}$ 处出现相变，即自由能密度的非解析性。由于 $f(\beta)$ 的一阶导数连续，这是一种二阶相变；但由于第 5.3 节将讨论的凝聚现象，它也常称为 “随机一阶” 相变。其他热力学势由第 2.2 节中的通常公式得到，画在图 5.3 中。

两个温度区域（或 “相”）$\beta \le \beta_c$ 和 $\beta > \beta_c$，具有不同的定性性质，用热力学势最容易刻画。

- 在高温相 $T \ge T_c$（等价于 $\beta \le \beta_c$），能量密度和熵密度为 $u(\beta) = -\beta/2$、$s(\beta) = \log 2 - \beta^2/4$。对 Boltzmann 测度起重要作用的构型，其能量为 $E_i \approx -N\beta/2$。具有这种能量密度的构型数目指数级地多（在 $\varepsilon = -\beta/2$ 处，微正则熵密度 $s(\varepsilon)$ 严格为正），Boltzmann 测度大致均匀地分配在这些构型之间。在高温极限 $T \to \infty$（$\beta \to 0$），Boltzmann 测度变为均匀分布，并如预期得到 $u(\beta) \to 0$（因为几乎所有构型的 E_i/N 都接近 0）及 $s \to \log 2$。

- 在低温相 $T < T_c$（$\beta > \beta_c$），热力学势为常数：$u(\beta) = -\varepsilon_*$、$s(\beta) = 0$。重要构型具有最低能量密度，即 $E_i/N \approx -\varepsilon_*$。热力学由相对较小的一组构型主导，其数目并不随 N 指数增长（熵密度为零）。

译注： “严格为正” 的高温描述需排除临界点 $\beta = \beta_c$，此点熵密度为零。式 (5.15) 的自由能密度在 $\beta = 0$ 需取极限理解，不能直接代入含 $1/\beta$ 的表达式。

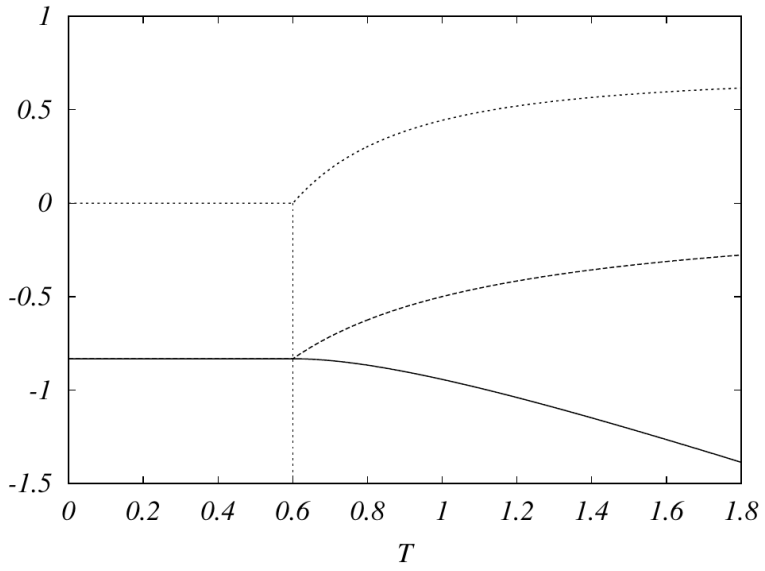


图 5.3: REM 的热力学: 自由能密度（实线）、能量密度（虚线）和熵密度（点线）随温度 $T = 1/\beta$ 的变化。相变发生在 $T_c = 1/(2\sqrt{\log 2}) \approx 0.6005612$。取自 Part B PDF 第 7 页（原印刷页 99）。

习题 5.2. 从把 *REM* 视作自旋玻璃简单版本的原始动机出发，可以定义存在磁场 B 时的 *REM* 推广。将 2^N 个构型分为 $N+1$ 组，每组以 *"磁化强度"* $M \in \{-N, -N+2, \ldots, N-2, N\}$ 标记，包含 $\binom{N}{(N+M)/2}$ 个构型。其能量 $\{E_j\}$ 是独立 *Gaussian* 变量，与式 (5.1) 一样具有方差 $\sqrt{N/2}$，而均值 $\mathbb{E}E_j = -MB$ 取决于 j 所属的组。证明在 β, B 平面上存在相变线 $\beta_c(B)$，使得

$$\frac{1}{N}\mathbb{E}M = \begin{cases} \tanh[\beta B], & \beta \le \beta_c(B), \\ \tanh[\beta_c(B) B], & \beta > \beta_c(B), \end{cases} \tag{5.16}$$

并画出磁化率 $\frac{dM}{dB}\big|_{B=0}$ 随 $T = 1/\beta$ 的变化。

译注： 源 PDF 此处确把 "方差" 写为 $\sqrt{N/2}$，与式 (5.1) 的方差 $N/2$ 不同；可能把标准差与方差混淆。原式 (5.16) 的 $\mathbb{E}M$ 还未显式区分热平均和样本平均，且该分段表达式应结合热力学极限理解；有限 N 下一般不是精确等式。

习题 5.3. 考虑 *REM* 的一种推广，能量的概率密度函数不是 *Gaussian*，而是

$$P(E) \propto \exp[-C|E|^{\delta}],$$

其中 $\delta > 0$。证明，为使热力学势具有广延性，应将 C 缩放为 $C = N^{1-\delta}\widehat{C}$（即在固定 $\widehat{C}$ 下取热力学极限 $N \to \infty$）。计算临界温度和基态能量密度。$\delta > 1$ 与 $\delta < 1$ 两种情形有何定性区别？

5.3 凝聚现象

低温相中，一组数目以次指数速度增长的构型主导 Boltzmann 测度；我们说测度凝聚在这些构型上。在其他玻璃相中也会遇到这种情形，[6]而它通常使寻找重要构型变得十分困难。为了量化凝聚，可以由 Boltzmann 权重 (5.2) 计算参与比 $Y_N(\beta)$：

$$Y_N(\beta) \equiv \sum_{j=1}^{2^N} p_j^2 = \left[\sum_j e^{-2\beta E_j}\right]\left[\sum_j e^{-\beta E_j}\right]^{-2}. \tag{5.17}$$

可将 $1/Y_N(\beta)$ 视为对测度有贡献的 “有效” 构型数目的某种估计。如果测度在 r 个能级上均匀分布，就有 $Y_N(\beta) = 1/r$。

参与比可写为 $Y_N(\beta) = Z_N(2\beta)/Z_N(\beta)^2$，其中 $Z_N(\beta)$ 为逆温度 β 时的配分函数。上一节的分析表明：当 $\beta < \beta_c$ 时，$Z_N(\beta) \doteq \exp[N(\log 2 + \beta^2/4)]$，且涨落很小（参见第 5.2.1 节末尾）；当 $\beta > \beta_c$ 时，$Z_N(\beta) \doteq \exp[N\beta\sqrt{\log 2}]$。这表明，高温相 $\beta < \beta_c$ 中几乎所有样本的 $Y_N(\beta)$ 都随 N 指数级地小，与高温下测度不凝聚一致。相反，我们将看到，低温相中 $Y_N(\beta)$ 为有限量，并随样本涨落。

低温相中 $\mathbb{E}Y$ 的计算稍显复杂（下文省略其自变量 N, β）。它要求精细控制满足 $E_i/N \approx -\varepsilon_*$ 的能级 E_i。*这里概述计算主线，细节留给读者作为习题。使用积分表示

$$1/Z^2 = \int_0^\infty dt\, t \exp(-tZ),$$

得到（$M = 2^N$）：

$$\mathbb{E}Y = M\mathbb{E}\int_0^\infty dt\, t \exp[-2\beta E_1] \exp\left[-t\sum_{i=1}^{M} e^{-\beta E_i}\right] \tag{5.18}$$

$$= M\int_0^\infty dt\, t\, a(t)[1-b(t)]^{M-1}, \tag{5.19}$$

其中

$$a(t) \equiv \int dP(E)\, \exp[-2\beta E - te^{-\beta E}], \tag{5.20}$$

$$b(t) \equiv \int dP(E)\, [1 - \exp(-te^{-\beta E})], \tag{5.21}$$

$P(E)$ 为 Gaussian 分布 (5.1)。当 N 很大时，$\mathbb{E}Y$ 的主导贡献来自 $E = -N\varepsilon_0 + u$ 和 $t = \theta\exp(-N\beta\varepsilon_0)$ 的区域，其中 u, θ 在 $N \to \infty$ 时保持有限，并定义

$$\varepsilon_0 = \varepsilon_* - \frac{1}{2\varepsilon_*}\log\sqrt{\pi N}. \tag{5.22}$$

注意，ε_0 由条件 $2^N P(-N\varepsilon_0) = 1$ 确定，可视为对最低能量构型的能量密度的更精细估计。在

[6]类比后面将遇到的类似情况，我们也把 REM 的低温相称为玻璃相。

$E=-N\varepsilon_0+u$ 区域，可将函数 $P(E)$ 替换为 $2^{-N}e^{\beta_c u}$，得到

$$\begin{aligned} a(t) &\approx \frac{1}{M}e^{2N\beta\varepsilon_0}\int_{-\infty}^{+\infty} du\, e^{\beta_c u-2\beta u-ze^{-\beta u}} \\ &= \frac{e^{2N\beta\varepsilon_0}}{M\beta}z^{\beta_c/\beta-2}\Gamma(2-\beta_c/\beta), \\ b(t) &\approx \frac{1}{M}\int_{-\infty}^{+\infty} du\, e^{\beta_c u}[1-\exp(-ze^{-\beta u})] \\ &= -\frac{1}{M\beta}z^{\beta_c/\beta}\Gamma(-\beta_c/\beta), \end{aligned} \tag{5.23}$$

其中 $\Gamma(x)$ 是 Euler Gamma 函数。注意，用 $2^{-N}e^{\beta_c u}$ 替换 $P(E)$ 不会造成问题，因为由此得到的式 (5.23) 中两个积分在大 u 处收敛。**译注：**原式 (5.22) 的修正项缺少尺度因子：由所述条件精确解得 $\varepsilon_0^2=\log 2-\log(\pi N)/(2N)$，因而大 N 展开为 $\varepsilon_0=\varepsilon_*-\log\sqrt{\pi N}/(2N\varepsilon_*)+O((\log N)^2/N^2)$。原文未定义 z，它应与前面缩放变量 θ 对照；本译稿保留原记号。所述 $b(t)$ 积分收敛还要求低温条件 $\beta>\beta_c$。

当 N 很大时，式 (5.19) 中的 $[1-b(t)]^{M-1}$ 可近似为 $e^{-Mb(t)}$，最终得到

$$\begin{aligned} \mathbb{E}Y &= M\int_0^{\infty} dt\, t\, a(t)e^{-Mb(t)} \\ &= \frac{1}{\beta}\Gamma\left(2-\frac{\beta_c}{\beta}\right)\int_0^{\infty} dz\, z^{\beta_c/\beta-1}\exp\left[\frac{1}{\beta}\Gamma\left(-\frac{\beta_c}{\beta}\right)z^{\beta_c/\beta}\right] \\ &= 1-\beta_c/\beta, \end{aligned} \tag{5.24}$$

其中使用了式 (5.23) 中的近似表达式；这些等式均在忽略 $N\to\infty$ 时消失的修正项的意义下成立。因此得到：

命题 5.3. *在 REM 中，参与比的期望为*

$$\mathbb{E}Y=\begin{cases} 0, & T>T_c, \\ 1-T/T_c, & T\le T_c. \end{cases} \tag{5.25}$$

译注：此为热力学极限结果，有限 N 时 $\sum_j p_j^2\ge 2^{-N}>0$，不能将高温相的 0 视为有限系统等式。临界点需由极限另行处理，不能直接套用上述要求 $\beta>\beta_c$ 的积分。

这给出了 Boltzmann 测度凝聚程度的定量刻画：随着 T 降低，凝聚从相变温度 T_c 开始。温度进一步降低时，参与比 Y 增大，意味着测度集中到越来越少的构型上，直到 $T=0$ 时只有一个构型有贡献，$Y=1$。

通过参与比，我们对低温相有了初步的定性和定量描述。事实上，该相中重要构型的能量具有许多有趣的概率性质，我们将在第?? 章再作讨论。

5.4 关于淬火平均和退火平均的说明

上一节发现 REM 具有自平均性，因此可以讨论一般样本的热力学。

热力学势的自平均性十分常见，但对于更复杂的系统，精确计算它们通常很困难。这里讨论这类情形中经常使用的一种近似，即所谓的退火平均。自由能密度具有自平均性时，几乎所

有样本的 f_N 值大致相同，可以通过其期望计算；这个期望称为淬火平均 $f_{N,q}$：

$$f_{N,q} = \mathbb{E} f_N = -\frac{T}{N} \mathbb{E} \log Z_N. \tag{5.26}$$

由于 f_N 正比于配分函数的对数，这个平均一般很难计算，而退火平均容易得多：

$$f_{N,a} = -\frac{T}{N} \log(\mathbb{E} Z). \tag{5.27}$$

下面对 REM 计算它。从配分函数 (8.1) 出发，得到

$$\mathbb{E} Z_N = \mathbb{E} \sum_{i=1}^{2^N} e^{-\beta E_i} = 2^N \mathbb{E} e^{-\beta E} = 2^N e^{N\beta^2/4}, \tag{5.28}$$

从而 $f_{N,a}(\beta) = -\beta/4 - \log 2/\beta$。[7]

将它与式 (5.15) 中的正确自由能密度比较。退火自由能密度 $f_a(\beta)$ 总不大于正确结果，这正符合 Jensen 不等式（注意对数为凹函数）。对于 REM 及少数其他特别简单的问题，它在高温相 $T > T_c$ 给出正确结果，却无法识别相变；在低温相，它错误地预测自由能密度是 $T > T_c$ 表达式的解析延拓。特别地，当 $T < T_c$ 时，它给出负的熵密度 $s_a(\beta) = \log 2 - \beta^2/4$，参见图 5.2。

对于有限构型空间上的系统，负熵不可能出现，这可从熵的定义看出。因此它标志着近似失效，原因也容易理解。给定一个自由能密度为 f 的样本，配分函数表现为 $Z_N = \exp(-\beta N f_N)$。自平均性意味着 f_N 的样本间涨落很小，但这些涨落确实存在，并由于指数中的因子 N 而在配分函数中得到放大。这意味着配分函数的退火平均可能由一些十分稀有的样本（f_N 异常低的样本）主导。例如考虑低温极限。我们已知，几乎所有样本的最低能量密度构型都位于 $E_i \approx -N\varepsilon_*$。然而，存在异常样本，其中某个构型的最小能量更低，为 $E_i = -N\varepsilon$、$\varepsilon > \varepsilon_*$。这些样本指数级罕见（出现概率 $\doteq 2^N e^{-N\varepsilon^2}$）；对淬火平均来说它们无关紧要，却主导退火平均。

再简要说明一下术语。“淬火” 和 “退火” 来源于材料热处理，例如合金冶金：淬火是通过将样本从高温骤然降到低温来制备样本。此后原子的位置不再改变；给定样本由位于某些随机位置的原子构成（忽略微小振动）。相反，退火过程中逐渐冷却合金，各种原子会找到有利的位置。在 REM 中，能级 E_i 是淬火的：对于每个给定样本，它们取某些固定值，类似淬火合金中的原子位置。在退火近似中，则将构型 i 和能量 E_i 同等对待，令它们服从由 Boltzmann 分布给出的联合概率分布。我们称变量 E_i 被热化了，类似退火合金中的原子位置。[8]

一般而言，对于构型空间有限的任何系统，都可用退火平均求自由能的下界。例如，利用对所有温度 $T = 1/\beta$ 和规模 N 成立的两个简单关系，可以得到有用的结果：

$$f_{N,q}(T) \geq f_{N,a}(T), \qquad \frac{df_{N,q}(T)}{dT} \leq 0. \tag{5.29}$$

如上所述，第一个关系由 Jensen 不等式得到；第二个关系则在对淬火无序平均后，由正则熵的非负性得到，参见式 (2.22)。

特别地，对于优化问题，即温度趋零的极限，退火平均给出一般界：

[7]译注：原文此处引用式 (8.1)，本章配分函数实际定义于式 (5.3)；保留原引用以供版本核查。

[8]译注：退火联合分布还包含原有无序分布作为参考测度，即对 $(i, \{E_j\})$ 的联合权重应与原无序概率乘以 $e^{-\beta E_i}$ 成正比；“Boltzmann 分布” 并不意味着抛弃这一无序先验。

命题 5.4. 基态能量密度

$$u_N(T=0) \equiv \frac{1}{N}\mathbb{E}\left[\min_{x\in\mathcal{X}^N} E(x)\right] \tag{5.30}$$

满足 $u_N(0) \geq \max_{T\in[0,\infty]} f_{N,a}(T)$。

证明. 将退火自由能密度 $f_{N,a}(T)$ 视为温度 $T = 1/\beta$ 的函数。对于任意给定样本，由一般关系 (2.23)，自由能是 T 的凹函数。容易证明，退火平均也具有同样性质。令 T_* 为 $f_{N,a}(T)$ 达到最大值的温度，以 $f^*_{N,a}$ 表示最大值。若 $T_* = 0$，则 $u_N(0) = f_{N,q}(0) \geq f^*_{N,a}$。若 $T_* > 0$，则

$$u_N(0) = f_{N,q}(0) \geq f_{N,q}(T_*) \geq f_a(T_*), \tag{5.31}$$

其中用了式 (5.29) 中的两个不等式。 □

译注： 原文引用 (2.23) 的温度/逆温度变量需核查；自由能对 T 的凹性可在适当有限矩条件下从联合系综得到。式 (5.31) 末项按原文省略 N，在本证明中应与 $f_{N,a}$ 对照。退火配分函数可能在某些温度发散，最大值存在及端点值须按定义域处理；下界本身可由两条不等式对每个允许温度逐点推出，无需预设最大值可达。

在 REM 中，这一结果立即给出 $u(0) \geq \max_\beta[-\beta/4 - \log 2/\beta] = -\sqrt{\log 2}$，而这实际上是一个紧界。

5.5 注释

注释

REM 由 Derrida 于 1980 年提出（Derrida, 1980），是某类自旋玻璃系统的一种极端情形。这里遵循他利用微正则熵的原始解法。更多细致计算可参阅 Derrida（Derrida, 1981），其中包括习题 2 的解答。

凝聚公式 (5.3)（原文如此）最早出现在 Gross 和 Mézard（Gross and Mézard, 1984）中，是复本计算的一项应用；我们将在第?? 章讨论复本计算。这里给出的参与比直接估计及其涨落，由 Mézard、Parisi 和 Virasoro（Mézard, Parisi and Virasoro, 1985）以及 Derrida 和 Toulouse（Derrida and Toulouse, 1985）发展而来。第?? 章还将讨论凝聚相中一些引人入胜且更细致的性质。

习题 3 展示了一种相变：$\delta > 1$ 时为二阶相变，$\delta < 1$ 时为一阶相变。解答可参阅 Bouchaud 和 Mézard（Bouchaud and Mézard, 1997）。

最后指出，在大多数物理文献中，作者不会明确写出例如通向式 (5.13) 的所有严格数学步骤，而更愿意采用流畅的叙述，着重说明基本思想。在复杂得多的模型中，要补齐相应的数学缺口可能十分困难。Talagrand 的近著（Talagrand, 2003）采取完全严格的观点，开篇介绍 REM，与这里及第?? 章的介绍形成很好的补充。[9]

[9]译注：草稿同时保留编号节标题 “5.5 Notes” 和其下 “Notes”，此处保留层级。章末 “凝聚公式 (5.3)（原文如此）” 指向本章配分函数，应与参与比及凝聚公式 (5.17)、(5.25) 对照；“习题 2、3” 的对应内容分别见习题 5.2、5.3。各处第?? 章及不能唯一确定的引文不补定；书目匹配差异见书后说明。

第六章　随机码系综

如第 1.6 节所述，信息论的基本问题之一是通过不可靠的通信信道实现可靠通信。纠错码通过向待传消息中系统地引入某种冗余来完成这一任务。Claude Shannon 的重大突破之一，是认识到*码系综*的重要性。他发现，与其给出达到某种性能的明确例子，不如构造一个以高概率具有良好性质的码系综，这容易得多。简言之，“随机” 设计比 “确定性” 设计容易得多。

同时，他定义并分析了最简单的这类系综，后来称为*随机码系综*（random code ensemble，RCE），有时也称 Shannon 系综。尽管极其简单，随机码系综却具有十分有趣的性质，特别是它能达到最优纠错性能。因此它给出了信道编码定理 “正向” 部分的证明：只要通信速率小于信道容量，就能以趋于零的错误概率通信。此外，它还是随机构造码的原型。后续章节将考察这种方法的若干例子，并以随机码系综为参照。

第 6.1 节介绍码系综思想并定义随机码系综，第 6.2 节描述其若干性质，第 6.3 节计算它在 BSC 上的性能。第 6.4 节将结果推广到一般离散无记忆信道。最后，第 6.5 节用简单的球堆积论证说明随机码系综的最优性。

6.1　码系综

一个纠错码由编码映射和解码映射组成。编码映射作用于信息序列，得到通过信道传输的编码消息；解码映射作用于带噪声的信道输出。为简单起见，本章始终假设待编码消息为 M 比特序列，编码产生长度 $N > M$ 的冗余比特序列。可能的码字（即编码映射的全部可能输出，是空间 $\{0,1\}^N$ 中的 2^M 个点）组成码本 $\mathcal{C}_N$。另一方面，用 $\mathcal{Y}$ 表示通信信道的输出字母表。采用记号

$$x : \{0,1\}^M \to \{0,1\}^N \qquad \text{编码映射,} \tag{6.1}$$

$$x^{\mathrm{d}} : \mathcal{Y}^N \to \{0,1\}^N \qquad \text{解码映射.} \tag{6.2}$$

注意，解码映射的定义与第 1.6 节略有不同。这里仅考虑解码过程中的困难部分，即由接收消息重建已发送的码字。要完成第 1.6 节所定义的解码，还应由码字恢复原始消息，但假设这是一项容易的任务（编码映射假设为单射）。

设计码系综的通常做法如下。

1. 在编码映射 (6.1) 的空间中定义一个子集。

2. 在该集合上赋予一个概率分布。

3. 对系综中的每个编码映射，定义对应的解码映射。

实践中，最后一步通常通过声明采用几种一般 “解码策略” 中的某一种来完成。下文介绍其中两种。

第一个例子是随机码系综。注意，形如 (6.1) 的编码映射共有 2^{N2^M} 个，因为必须为 2^M 个码字各指定 N 个比特。在 RCE 中，按均匀概率选取任意一个这样的编码映射。因此，码的构造如下：对于每个可能的信息消息 $m \in \{0,1\}^M$，抛掷无偏硬币 N 次，得到对应码字 $x^{(m)} = (x_1^{(m)}, \dots, x_N^{(m)})$，第 i 次结果赋给第 i 个坐标 $x_i^{(m)}$。

习题 6.1. 注意，根据这一定义，码不一定是单射：可能存在两个信息消息 $m_1 \neq m_2$，其码字相同，即 $x^{(m_1)} = x^{(m_2)}$。对于纠错码，这是令人不快的性质：每当发送 m_1 或 m_2 中任一消息时，即使没有噪声，接收者也无法区分它们。幸好，这类不幸的重合很少发生，即其数目远小于码字总数 2^M。满足 $x^{(m_1)} = x^{(m_2)}$ 的消息对 m_1, m_2 的期望数目是多少？全部码字互不相同的概率是多少？

译注： “重合比例小” 不等于 “整个编码以高概率为单射”；在生日碰撞尺度 $2M \approx N$ 附近，两种性质已明显不同。后文把码本视为具有 2^M 个元素的集合及采用均匀码字先验时，需区分消息标签计数和不同码字计数。

现在定义解码映射。介绍两种最重要且适用于大多数码的方案：*码字 MAP 解码*和*符号 MAP 解码*，其中 MAP 表示最大后验概率。两种方案都需要引入概率分布 $P(x \mid y)$，即给定接收消息 y 时 x 为信道输入的条件概率。对于转移概率为 $Q(y \mid x)$ 的无记忆信道，由 Bayes 公式可显式写出

$$P(x \mid y) = \frac{1}{Z(y)} \prod_{i=1}^{N} Q(y_i \mid x_i) P_0(x). \tag{6.3}$$

这里 $Z(y)$ 由归一化条件 $\sum_x P(x \mid y) = 1$ 确定，$P_0(x)$ 是 x 为待传消息的先验概率。本书始终假设发送者按均匀概率选择待传码字。因此当 $x \in \mathcal{C}_N$ 时，$P_0(x) = 1/2^M$，否则为 0。用公式表示，

$$P_0(x) = \frac{1}{|\mathcal{C}_N|} \mathbf{1}(x \in \mathcal{C}_N). \tag{6.4}$$

还可定义给定输出消息时已发送消息第 i 个比特的边缘分布 $P^{(i)}(x_i \mid y)$。对式 (6.3) 中所有 $j \neq i$ 的比特 x_j 求和，得到

$$P^{(i)}(x_i \mid y) = \sum_{x_{\setminus i}} P(x \mid y), \tag{6.5}$$

其中 $x_{\setminus i} \equiv \{x_j : j \neq i\}$。码字 MAP 解码输出最可能的已发送码字，即最大化分布 (6.3)：[1]

$$x^{\mathrm{w}}(y) = \arg\max_x P(x \mid y). \tag{6.6}$$

与之密切相关的策略是*最大似然解码*，即在 $x \in \mathcal{C}_N$ 上最大化 $Q(y \mid x)$。当待传码字的先验分布 $P_0(x)$ 如式 (6.4) 那样均匀时，它与码字 MAP 解码一致。

[1] 对并列情形（最大值简并）不指定处理方法，因为这对所考虑的编码问题无关紧要。严谨的读者可自行选择约定。

符号（或比特）*MAP* 解码输出各个最可能的已发送比特构成的序列，即分别最大化边缘分布 (6.5)：

$$x^{\mathrm{b}}(y) = \left(\arg\max_{x_1} P^{(1)}(x_1 \mid y), \ldots, \arg\max_{x_N} P^{(N)}(x_N \mid y) \right). \tag{6.7}$$

习题 6.2. *考虑码长 $N = 3$、码本大小 $|\mathcal{C}| = 4$ 的码，码字为 $x^{(1)} = 001$、$x^{(1)} = 101$、$x^{(1)} = 110$、$x^{(1)} = 111$。码率是多少？用该码在翻转概率 $p < 0.5$ 的二元对称信道（BSC）上传输。假设信道输出 $y = 000$，证明码字 MAP 解码得到码字 001。再用符号 MAP 解码第一个比特 x_1：证明仅当 p 足够小时，结果才与码字 MAP 解码一致。*

译注：原文四个码字都写为上标 (1)，此处照录，作为不同码字的标签应加以区分。

应注意，上述两种方案分别针对不同准则最优。码字 MAP 解码最小化第 1.6.2 节定义的平均块错误概率 P_B：对于信道分布 $Q(y \mid x)$，解码码字 $x^{\mathrm{d}}(y)$ 不等于发送码字的概率，再对发送码字取平均，即

$$P_B \equiv \frac{1}{|\mathcal{C}|} \sum_{x \in \mathcal{C}} \mathbb{P}[x^{\mathrm{d}}(y) \neq x]. \tag{6.8}$$

比特 MAP 解码最小化比特错误概率或误比特率（BER）P_b，即错误比特所占比例对发送码字的平均：

$$P_b \equiv \frac{1}{|\mathcal{C}|} \sum_{x \in \mathcal{C}} \frac{1}{N} \sum_{i=1}^{N} \mathbb{P}[x_i^{\mathrm{d}}(y) \neq x_i]. \tag{6.9}$$

*证明码字和符号 MAP 解码确实分别对上述准则最优，是一个简单习题，留给读者。

6.2 随机码系综的几何

先研究随机码系综的若干几何性质。码本定义系综中的码，它是 Hamming 空间 $\{0,1\}^N$ 中 2^M 个点（全部码字）的集合。

每个点均从 Hamming 空间按均匀概率抽取。关于 $\mathcal{C}_N$，最简单的问题是：假设置身于某个码字并观察周围，在给定 Hamming 距离处还有多少其他码字？[2]

可用相对于码字 $x_0 \in \mathcal{C}_N$ 的距离枚举函数 $\mathcal{N}_{x_0}(d)$ 回答这一问题：它定义为与 x_0 的 Hamming 距离等于 d，即 $d(x, x_0) = d$ 的码字 $x \in \mathcal{C}_N$ 的数目。

现在计算随机码的权重枚举函数的典型性质。最简单的量是平均距离枚举函数 $\mathbb{E}\mathcal{N}_{x_0}(d)$，平均取遍码系综。一般还应指定哪个码字为 x_0；但 RCE 中所有码字独立抽取，每个都在 Hamming 空间中均匀分布，因此无需指定，实际上可将 x_0 固定为全零码字 $000\cdots00$。于是问题变为：在 $\{0,1\}^N$ 中均匀随机抽取 $2^M - 1$ 个点，与 $00\cdots0$ 角点相距 d 的平均点数是多少？它就是点数 $2^M - 1$ 乘以 Hamming 空间中距全零点为 d 的“体积”比例 $2^{-N}\binom{N}{d}$：

$$\mathbb{E}\mathcal{N}_{x_0}(d) = (2^M - 1)2^{-N} \binom{N}{d} \doteq 2^{N[R-1+H_2(\delta)]}. \tag{6.10}$$

[2]两个点 $x, y \in \{0,1\}^N$ 的 Hamming 距离，是它们不同坐标的数目。

第二个表达式中引入了相对距离 $\delta \equiv d/N$ 和码率 $R \equiv M/N$，并在固定二者时考察 $N \to \infty$ 渐近。图 6.1 画出了函数 $R - 1 + H_2(\delta)$，它有时称为距离枚举函数的*增长率*。对于足够小的 $\delta < \delta_{\mathrm{GV}}$，增长率为负：与 x_0 相距很近的码字平均数随 N 指数趋零。由 Markov 不等式，在如此短距离内存在任一码字的概率在 $N \to \infty$ 时消失。距离 $\delta_{\mathrm{GV}}(R)$ 称为 *Gilbert–Varshamov 距离*，是 $R - 1 + H_2(\delta) = 0$ 的最小根。例如 $\delta_{\mathrm{GV}}(1/2) \approx 0.110278644$。

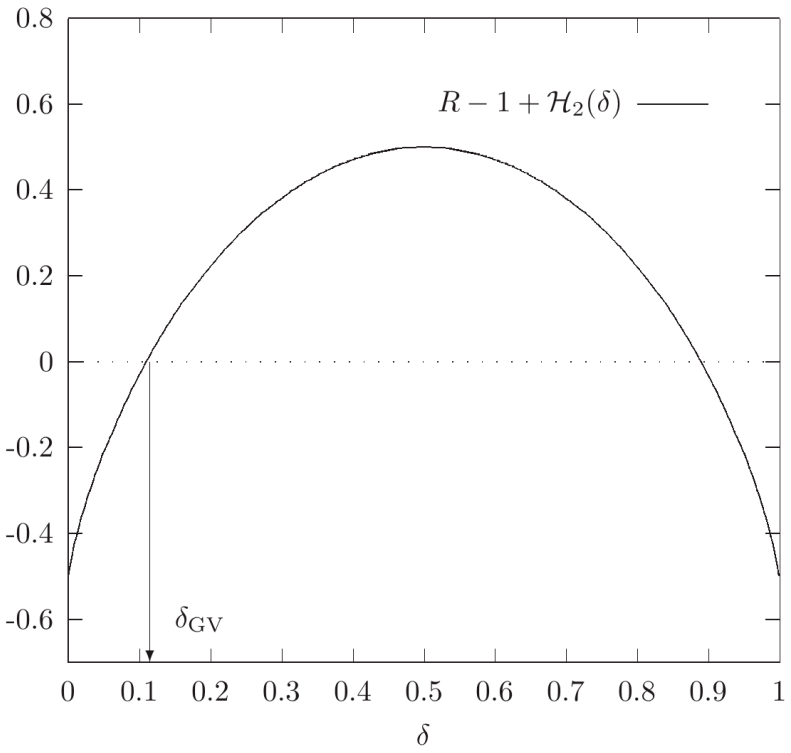


图 6.1: 码率 $R = 1/2$ 的随机码系综中，距离枚举函数的增长率随 Hamming 距离 $d = N\delta$ 的变化。取自 Part B PDF 第 17 页（原印刷 109）。

超过 Gilbert–Varshamov 距离，即 $\delta > \delta_{\mathrm{GV}}$ 时，码字平均数指数级地大，在 $\delta = 1/2$ 达到最大值：$\mathbb{E}\mathcal{N}_{x_0}(N/2) \doteq 2^{NR} = 2^M$。*利用与第 5.2 节研究 REM 时类似的论证，容易证明，在整个 $\delta_{\mathrm{GV}} < \delta < 1 - \delta_{\mathrm{GV}}$ 区间，权重枚举函数 $\mathcal{N}_{x_0}(d)$ 都紧密集中在其均值附近。这里 REM 构型变成码字，能量的角色由 Hamming 距离承担，Gaussian 能级分布则换为二项分布。图 6.2 给出了直观示意；注意，用有限维图像解释高维空间中的现象常会误导，必须谨慎使用。**译注：**原文先说其他码字，后给集合计数定义；式 (6.10) 排除了基准码字自身，并按消息标签计数重复抽取。“超过” 的指数增长叙述还应限于 $\delta < 1 - \delta_{\mathrm{GV}}$；在另一端的尾部同样是指数罕见。原文 “weight enumerator” 与 “distance enumerator” 交替使用，后者是相对于指定码字的距离计数。

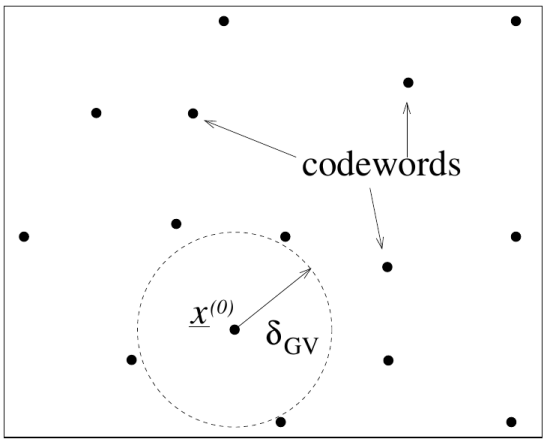


图 6.2: 随机码系综典型码的示意。码字是 Hamming 空间中的随机点。随机选一个码字并作半径 $N\delta$ 的球：$\delta < \delta_{\rm GV}(R)$ 时球内没有其他码字；$\delta > \delta_{\rm GV}(R)$ 时包含指数多个码字。译注：此为大码长下的典型描述。取自 Part B PDF 第 18 页（原印刷 110）。

习题 6.3. 随机码系综容易推广到其他非二元字母表。例如考虑 q 元字母表 $\mathcal{A} \equiv \{0, 1, 2, \ldots, q-1\}$。在 $\mathcal{A}^N$ 中按均匀概率抽取 2^M 个码字来构造码 $\mathcal{C}_N$。将两个码字间的距离 $d_q(x, y)$ 定义为序列 x, y 不同位置的数目。容易证明，平均距离枚举函数为

$$\mathbb{E}\mathcal{N}_{x_0}(d) \doteq 2^{N[R-\log_2 q+\delta\log_2(q-1)+H_2(\delta)]}, \tag{6.11}$$

其中 $\delta \equiv d/N$、$R \equiv M/N$。上式函数不再在 $\delta = 1/2$ 达到最大值。如何简单解释这一现象？

6.3 在二元对称信道上通信

现在分析 RCE 在图 1.4 定义的二元对称信道（BSC）上通信的性能。先考虑码字 MAP（等价于最大似然）解码器，再分析稍复杂的符号 MAP 解码器。最后，受统计物理类比启发，引入一种推广的解码策略。

6.3.1 码字 MAP 解码

对于 BSC，信道输入 x 和输出 y 均为长度 N 的比特序列。式 (6.3)、(6.4) 定义的给定输出 y 时码字 x 为信道输入的概率，仅依赖两向量间的 Hamming 距离 $d(x, y)$。以 p 表示信道翻转概率，则

$$P(x \mid y) = \frac{1}{C} p^{d(x,y)}(1-p)^{N-d(x,y)}\mathbf{1}(x \in \mathcal{C}_N), \tag{6.12}$$

其中 C 是只依赖 y 的归一化常数。不失一般性，假设 $p < 1/2$。因此，对 x 最大化 $P(x \mid y)$ 的码字 MAP 解码输出距离信道输出最近的码字。

由此，原通信问题获得了纯几何表述。在 $\{0,1\}^N$ 中抽取随机点集 $\mathcal{C}_N$，选取其中一个点（记为 x_0）通信。噪声扰动该向量，产生新点 y。解码就是在 $\mathcal{C}_N$ 中找到距 y 最近的点；只要它不是 x_0 就失败。块错误概率就是这一事件的概率。图 6.3 对此作了说明。

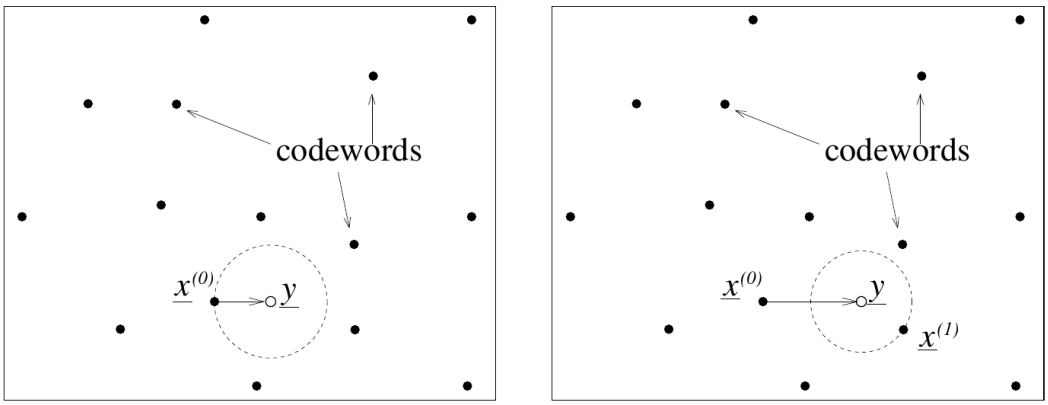


图 6.3: BSC 上码字 MAP 解码的示意。选定码字 x_0 并经带噪信道传输，输出为 y。若 x_0 与 y 距离足够小（左），寻找距 y 最近的码字即可可靠重建消息；否则（右），最近码字 x_1 与发送码字不同。取自 Part B PDF 第 19 页（原印刷 111）。

这一描述应使人立即明白：只要 p 低于某个有限阈值，块错误概率就在 $N \to \infty$ 极限下消失。上一节看到，以高概率，离 x_0 最近的其他码字 $x' \in \mathcal{C}_N \setminus \{x_0\}$ 距其约为 $N\delta_{\mathrm{GV}}(R)$。另一方面，y 由 x_0 各比特以概率 p 独立翻转得到，因此以高概率有 $d(y, x_0) \simeq Np$。由三角不等式，只要 $d(x_0, y) < d(x_0, x')/2$，x_0 就必为距 y 最近的码字，码字 MAP 解码因而成功。如果 $p < \delta_{\mathrm{GV}}(R)/2$，这一事件在 $N \to \infty$ 时以趋于 1 的概率发生，于是块错误概率趋零。

不过，上述论证高估了噪声的影响。虽然约 $N\delta_{\mathrm{GV}}(R)/2$ 个错误比特就可能导致解码失败，但它们必须出现在合适位置，才会让 y 更接近 x' 而不是 x_0。若错误位置均匀随机（BSC 正是如此），则很可能无害。高维空间中两种情形的差别尤为显著，下文分析将说明这一点。

$x^{(0)}$ 与 y 的距离是 N 个参数为 p 的独立同分布 Bernoulli 变量之和，因为每个比特以概率 p 翻转。由中心极限定理，对任意 $\varepsilon > 0$，不等式 $N(p-\varepsilon) < d(x^{(0)}, y) < N(p+\varepsilon)$ 在 $N \to \infty$ 时以趋于 1 的概率成立。其余 $2^M - 1$ 个码字与 $x^{(0)}$，从而与 y 完全无关；$\{y, x^{(1)}, \dots, x^{(2^M-1)}\}$ 是从 $\{0,1\}^N$ 的均匀分布抽取的 2^M 个独立同分布随机点。上一节分析表明，当 $\delta < \delta_{\mathrm{GV}}(R)$ 时，以趋于 1 的概率，这些其他码字均不在以 y 为心、半径 $N\delta$ 的球内；相反，若 $\delta > \delta_{\mathrm{GV}}(R)$，球内有随 N 指数增长数目的这类码字。

于是容易推断 RCE 的性能，参见图 6.4：若 $p < \delta_{\mathrm{GV}}(R)$，发送码字 $x^{(0)}$ 比其他所有码字更接近接收消息 y，解码成功。若噪声更大，$p > \delta_{\mathrm{GV}}(R)$，则指数多个码字比发送码字更接近 y，解码失败。注意，条件 $p < \delta_{\mathrm{GV}}(R)$ 等价于 $R < C_{\mathrm{BSC}}(p)$，其中 $C_{\mathrm{BSC}}(p) = 1 - H_2(p)$ 是翻转概率为 p 的 BSC 的容量。

6.3.2 符号 MAP 解码

符号 MAP 解码先计算第 i 个比特的边缘分布 $P^{(i)}(x_i \mid y)$，再对 x_i 最大化。由式 (6.12) 得

$$P^{(i)}(x_i \mid y) = \sum_{x_{\setminus i}} P(x \mid y) = \frac{1}{Z} \sum_{x_{\setminus i}} \exp\{-2B\, d(x, y)\}, \tag{6.13}$$

其中引入参数

$$B \equiv \frac{1}{2}\log\left(\frac{1-p}{p}\right), \tag{6.14}$$

及归一化常数

$$Z \equiv \sum_{x\in\mathcal{C}_N} \exp\{-2B\, d(x,y)\}. \tag{6.15}$$

式 (6.13) 表明，所有码字都对边缘分布作贡献，而非只有距 y 最近的码字。因此符号 MAP 解码的分析略复杂于码字 MAP 解码。**译注：** 式 (6.13) 最后求和应限制在与指定 x_i 一致的码字上，或在求和项中保留码本示性函数；原文把这一限制留在求和记号中隐含处理。以下取 $0 < p < 1/2$，端点按极限理解。

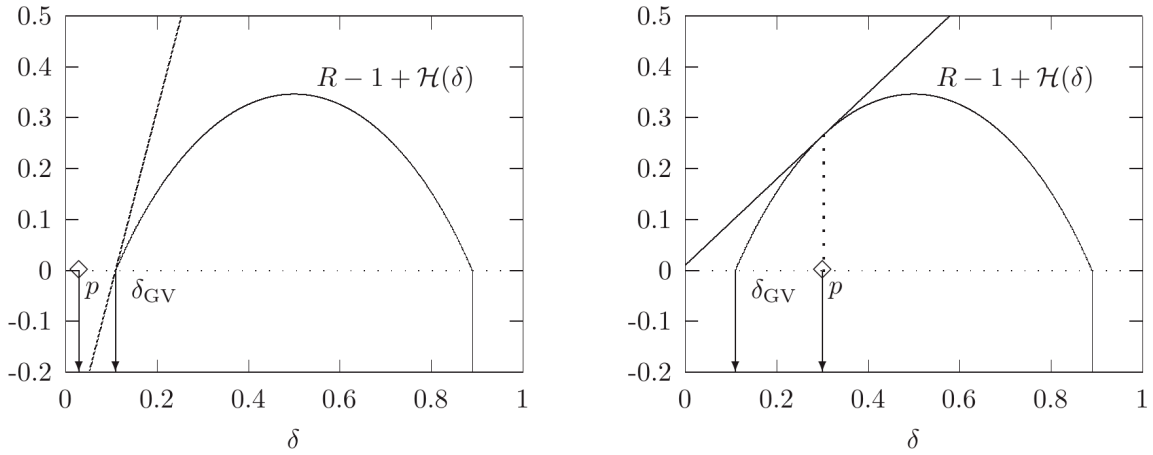


图 6.4: 距离枚举函数 $\widehat{\mathcal{N}}_y(d)$（距接收消息 $d = N\delta$ 的码字数目）的对数除以码长 N。码率 $R = 1/2$。同时给出两种噪声下发送码字的距离：左图 $p = 0.03 < \delta_{\mathrm{GV}}(1/2) \approx 0.110278644$，右图 $p = 0.3 > \delta_{\mathrm{GV}}(R)$。斜率 $2B = \log[(1-p)/p]$ 的切线决定哪些码字主导符号 MAP 解码器。取自 Part B PDF 第 21 页（原印刷 113）。

先估计归一化常数 Z。将发送码字 $x^{(0)}$ 的贡献与错误码字 $x^{(1)}, \ldots, x^{(2^M-1)}$ 的贡献分开较为方便：

$$Z = e^{-2Bd(x^{(0)},y)} + \sum_{d=0}^{N} \widehat{\mathcal{N}}_y(d) e^{-2Bd} \equiv Z_{\mathrm{corr}} + Z_{\mathrm{err}}, \tag{6.16}$$

其中 $\widehat{\mathcal{N}}_y(d)$ 为距 y 为 d 的错误码字数目。$x^{(0)}$ 的贡献容易估计：由中心极限定理，$d(x^{(0)},y) \simeq Np$，因而 Z_{corr} 以高概率接近 e^{-2NBp}。更精确地，对任意 $\varepsilon > 0$，在 $N \to \infty$ 时以趋于 1 的概率有 $e^{-N(2Bp+\varepsilon)} \le Z_{\mathrm{corr}} \le e^{-N(2Bp-\varepsilon)}$。

对于 Z_{err}，分两步：先计算距离枚举函数 $\widehat{\mathcal{N}}_y(d)$，再对 d 求和。第 6.2 节已计算距离枚举函数。与码字 MAP 的分析一样，相对于信道输出 y 而非某个码字测距不会改变结果，因为 y 独立于错误码字。因此，在 $\delta_{\mathrm{GV}}(R) < \delta \equiv d/N < 1 - \delta_{\mathrm{GV}}(R)$ 内，$\widehat{\mathcal{N}}_y(d)$ 指数级地大，在其外则以高概率为零。而在区间内部，它紧密集中在式 (6.10) 给出的均值附近。于是可用鞍点法计

算式 (6.16) 的 d 求和，这与第 5.2 节估计 REM 自由能十分相似。粗略地说，

$$\begin{aligned} Z_{\mathrm{err}} &= \sum_{d=0}^{N} \widehat{\mathcal{N}}_y(d) e^{-2Bd} \\ &\simeq N \int_{\delta_{\mathrm{GV}}}^{1-\delta_{\mathrm{GV}}} e^{N[(R-1)\log 2 + H(\delta) 2B\delta]}\, d\delta \doteq e^{N\phi_{\mathrm{err}}}, \end{aligned} \tag{6.17}$$

其中

$$\phi_{\mathrm{err}} \equiv \max_{\delta \in [\delta_{\mathrm{GV}}, 1-\delta_{\mathrm{GV}}]} [(R-1)\log 2 + H(\delta) - 2B\delta]. \tag{6.18}$$

译注： 原式 (6.17) 的积分指数确将 $H(\delta)$ 与 $2B\delta$ 并置，缺少式 (6.18) 中的减号；原式保留。这里的 H 应使用自然对数熵，与前面 H_2 区分。

⋆读者可按第 5.2 节的思路补齐上述推导的数学细节。最终结论是，$N \to \infty$ 时 Z_{err} 以高概率接近 $e^{N\phi_{\mathrm{err}}}$。

考察表达式 (6.18)，参见图 6.4。若最大值在区间内部达到，则位置 δ_* 由驻点条件 $H'(\delta_*) = 2B$ 决定，给出 $\delta_* = p$。否则最大值必在 $\delta_* = \delta_{\mathrm{GV}}$ 达到，注意 $B > 0$。分别计算，得到

$$\phi_{\mathrm{err}} = \begin{cases} -\delta_{\mathrm{GV}}(R) \log \frac{1-p}{p}, & p < \delta_{\mathrm{GV}}, \\ (R-1)\log 2 - \log(1-p), & \text{其他情形}. \end{cases} \tag{6.19}$$

现在比较 Z_{corr} 与 Z_{err}。噪声低（p 小）时，发送码字与接收消息足够接近，因而主导式 (6.16) 的求和；噪声较大时，指数多个错误码字压过 $x^{(0)}$ 的贡献。更精确地，以高概率有

$$Z = \begin{cases} Z_{\mathrm{corr}}[1 + e^{-\Theta(N)}], & p < \delta_{\mathrm{GV}}, \\ Z_{\mathrm{err}}[1 + e^{-\Theta(N)}], & \text{其他情形}, \end{cases} \tag{6.20}$$

其中 $\Theta(N)$ 指数取正值。[3]

再考察式 (6.13)，同样分离发送码字贡献：

$$P^{(i)}(x_i \mid y) = \frac{1}{Z}[Z_{\mathrm{corr}} \mathbf{1}(x_i = x_i^{(0)}) + Z_{\mathrm{err},x_i}], \tag{6.21}$$

其中定义

$$Z_{\mathrm{err},x_i} = \sum_{z \in \mathcal{C}_N \setminus \{x^{(0)}\}} e^{-2Bd(z,y)} \mathbf{1}(z_i = x_i). \tag{6.22}$$

注意 $Z_{\mathrm{err},x_i} \le Z_{\mathrm{err}}$。结合式 (6.20)，当 $p < \delta_{\mathrm{GV}}(R)$ 时，得到

$$P^{(i)}(x_i = x_i^{(0)} \mid y) = 1 - e^{-\Theta(N)}, \qquad P^{(i)}(x_i \neq x_i^{(0)} \mid y) = e^{-\Theta(N)}.$$

此时符号 MAP 解码器正确输出发送比特 $x_i^{(0)}$。强调一下：此结果在 $N \to \infty$ 时以趋于 1 的概率成立。具体而言，仍存在不好的码选择和特别不利的信道实现 y，使 $P^{(i)}(x_i = x_i^{(0)} \mid y) < 1/2$，解码器失败；但这一事件的概率（即误比特率 P_b）在 $N \to \infty$ 时消失。

[3]译注：两项在阈值 $p = \delta_{\mathrm{GV}}$ 处的指数阶相同，不能直接把原文 “其他情形” 解释为包含该临界点的指数压制结论。

若 $p > \delta_{\mathrm{GV}}(R)$ 会怎样? 与归一化常数的论证类似, 容易证明错误码字主导边缘分布 (6.21)。直观上这意味着解码器失败。下文概述的更详细计算表明, $N \to \infty$ 极限下误比特率为

$$P_b = \begin{cases} 0, & p < \delta_{\mathrm{GV}}(R), \\ p, & \delta_{\mathrm{GV}}(R) < p < 1/2. \end{cases} \tag{6.23}$$

超过阈值后, 误比特率与信息消息不编码而直接通过 BSC 传输时相同, 码已无用。

完整计算 $p > \delta_{\mathrm{GV}}(R)$ 时的 P_b 较长, 至少本章方法如此。这里给出启发式但基本正确的说明, 严格证明留作下面的习题。如前所述, 可忽略式 (6.21) 中 Z_{corr}。不失一般性, 假设 $x_i^{(0)} = 0$。若 $Z_{\mathrm{err},0} > Z_{\mathrm{err},1}$, 解码器成功, 反之则失败。需要分两种情形: $y_i = 0$, 概率为 $1-p$; 或者 $y_i = 1$, 概率为 p。第一种情形中,

$$\begin{aligned} Z_{\mathrm{err},0} &= \sum_{z \in \mathcal{C}_N \setminus \{x^{(0)}\}} \mathbf{1}(z_i = 0) e^{-2B d_i(y,z)}, \\ Z_{\mathrm{err},1} &= e^{-2B} \sum_{z \in \mathcal{C}_N \setminus \{x^{(0)}\}} \mathbf{1}(z_i = 1) e^{-2B d_i(y,z)}, \end{aligned} \tag{6.24}$$

其中 $d_i(x,y)$ 为除 i 外满足 $x_j \neq y_j$ 的位置 j 的数目。上述求和是独立同分布随机变量, 且紧密集中在其均值附近。由于 $B > 0$, 这以高概率给出 $Z_{\mathrm{err},0} > Z_{\mathrm{err},1}$。因此 $y_i = 0$ 时解码器成功; 类似地, 若 $y_i = 1$, 以高概率解码失败, 所以当 $p > \delta_{\mathrm{GV}}(R)$ 时误比特率趋于 p。

习题 6.4. *严格地说, 上述论证的薄弱之处, 是没有估计 $Z_{\mathrm{err},0/1}$ 的涨落。可沿下述路线补齐推导。*

- *定义 $X_0 \equiv Z_{\mathrm{err},0}$、$X_1 \equiv e^{2B} Z_{\mathrm{err},1}$, 证明 X_0, X_1 独立同分布。*
- *定义适当的距离枚举函数 $\mathcal{N}_{0/1}(d)$, 使 $X_{0/1} = \sum_d \mathcal{N}_{0/1}(d) e^{-2Bd}$ 成立。*
- *证明在适当的 d 范围内, $\mathcal{N}_{0/1}(d)$ 明显偏离均值的概率极低, 且比指数更小。*
- *推出 $X_{0/1}$ 发生明显涨落的概率极低。最后两点可按第 五章讨论 REM 的思路处理。*

译注: 固定码字总数时, 两个求和按同一批随机码字的第 i 位分组, 组数互补, 有限 N 下一般不独立; 例如单个错误码字对两组的贡献互斥。对称性给出同分布, 但不能代替独立性。原习题首项及前文断言照录, 集中性论证需避免依赖这一错误的精确独立结论。

6.3.3 有限温度解码

边缘分布 $P(x_i \mid y)$ 的表达式 (6.13) 很像 Boltzmann 平均。这一类比启发了介于上述两种 "经典" MAP 策略之间的推广: 有限温度解码。先在 BSC 情形下定义它。令非负数 β 扮演逆温度的角色, $y \in \{0,1\}^N$ 为信道输出, 定义概率分布

$$P_\beta(x) = \frac{1}{Z(\beta)} e^{-2\beta B d(y,x)} \mathbf{1}(x \in \mathcal{C}_N), \qquad Z(\beta) \equiv \sum_{x \in \mathcal{C}_N} e^{-2\beta B d(x,y)}, \tag{6.25}$$

其中 B 仍由式 (6.14) 与噪声水平 p 关联。该分布依赖信道输出 y：对于每个接收消息，有限温度解码器都构造相应的 $P_\beta(x)$，为简便起见未显式写出此依赖。令 $P_\beta^{(i)}(x_i)$ 为 x 按 $P_\beta(x)$ 分布时 x_i 的边缘分布，新解码器输出

$$x^\beta = \left(\arg\max_{x_1} P_\beta^{(1)}(x_1), \ldots, \arg\max_{x_N} P_\beta^{(N)}(x_N) \right). \tag{6.26}$$

与前几节一样，在并列情形，即 $P_\beta^{(i)}(0) = P_\beta^{(i)}(1)$ 时，读者可自行选择处理约定。

两个 β 值特别有趣：$\beta = 1$ 和 $\beta = \infty$。若 $\beta = 1$，$P_\beta(x)$ 就是给定信道输出时信道输入的条件分布 $P(x \mid y)$，参见式 (6.12)。因此对于任意 y，符号 MAP 解码都与 $\beta = 1$ 的有限温度解码一致：$x_i^{\beta=1} = x^{\mathrm{b}}$。[4]

若 $\beta = \infty$，分布 (6.25) 集中到距离 y 最近的码字上。特别地，若最近码字唯一，$\beta = \infty$ 的有限温度解码与码字 MAP 解码一致，即 $x^{\beta=\infty} = x^{\mathrm{w}}$。

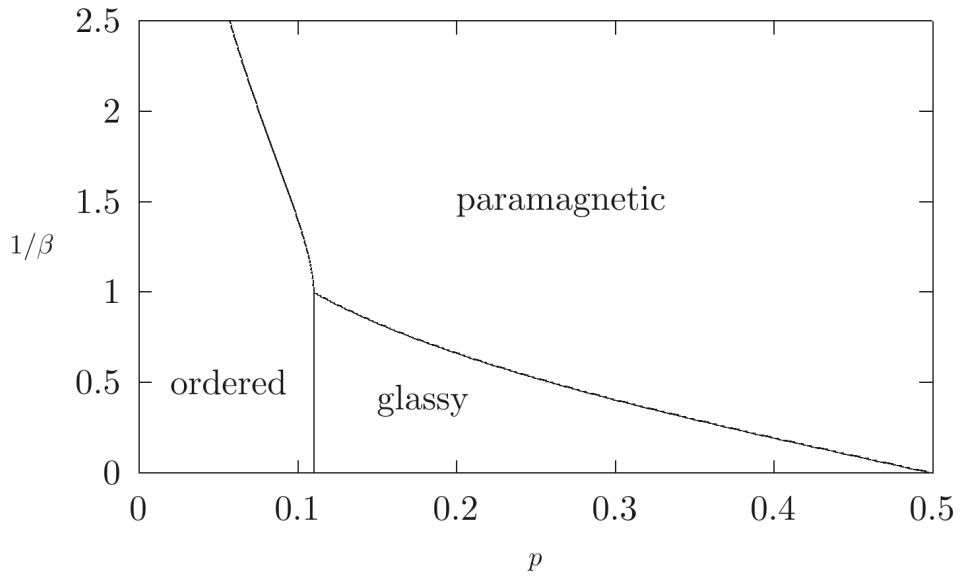


图 6.5: 码率 1/2 的随机码系综在有限温度解码下的相图。码字 MAP 和比特 MAP 分别对应 $1/\beta = 0$ 与 $1/\beta = 1$。在此温度区间，无错误（有序）相的边界是竖直的。译注：图内 paramagnetic、ordered、glassy 分别为顺磁、有序、玻璃态。取自 Part B PDF 第 25 页（原印刷 117）。

⋆对任意 β，均可用上一节的方法分析 RCE 在大 N 极限下的有限温度解码性能。图 6.5 汇总了结果，给出有限温度解码相图。存在三个行为迥异的区域，对应不同的相。

1. 低噪声 $p < \delta_{\mathrm{GV}}(R)$、低温（$\beta$ 足够大）的“完全有序”相。此时解码器有效：分布 $P_\beta(x)$ 由发送码字 $x^{(0)}$ 主导，更精确地，$P_\beta(x^{(0)}) = 1 - \exp\{-\Theta(N)\}$。比特和块错误率在 $N \to \infty$ 时趋零。

2. 较高噪声 $p > \delta_{\mathrm{GV}}(R)$、低温（$\beta$ 足够大）的“玻璃”相。发送码字权重可忽略，$P_\beta(x^{(0)}) = \exp\{-\Theta(N)\}$。误比特率有远离 0 的下界，块错误率在 $N \to \infty$ 时趋于 1。测度 $P_\beta(x)$ 由距接收消息 y 最近且不同于正确码字的码字主导，其 Shannon 熵 $H(P_\beta)$ 对 N 次线性增长。这与 REM 低温相中的“测度凝聚”现象密切相关。

[4]译注：原文此等式左侧带分量指标 i，右侧为整个向量；若比较分量，右侧亦应带 i。

3. 高温（β 足够小）的“熵主导”相（顺磁相）。比特和块错误率的行为与玻璃相类似，且 $P_\beta(x^{(0)}) = \exp\{-\Theta(N)\}$。但此时测度由距接收消息 $d \simeq N\delta_*$ 的码字主导，这一距离大于最小距离，其中 $\delta_* = p^\beta/[p^\beta + (1-p)^\beta]$。特别地，$\beta = 1$ 时 $\delta_* = p$，$\beta = 0$ 时 $\delta_* = 1/2$。第一种情形恢复符号 MAP 的结果；第二种情形中，$P_{\beta=0}(x)$ 在码字上均匀分布，该分布下到接收消息的距离以高概率接近 $N/2$。这一相中，Shannon 熵 $H(P_\beta)$ 随 N 线性增长。

译注：三个相的指数主导描述适用于各相内部，临界边界需另行处理；$\beta = 0$ 的所有边缘均为极限或依赖具体码本，处理并列的约定可能影响解码决定，不应仅从均匀测度推出严格统一的有限码长错误率。

有限温度解码的定义容易推广到其他信道。设 $P(x \mid y)$ 为式 (6.3) 显式给出的条件分布。对 $\beta > 0$，定义[5]

$$P_\beta(x) = \frac{1}{Z(\beta)} P(x \mid y)^\beta, \qquad Z(\beta) \equiv \sum_x P(x \mid y)^\beta. \tag{6.27}$$

解码器仍按式 (6.26) 决定第 i 个比特。$P_\beta(x)$ 是条件分布 $P(x \mid y)$ 的一种“形变”。大 β 时，给高概率待传消息更大权重；小 β 时，数量最多的码字主导求和。*稍作思考即可看出，与 BSC 一样，$\beta = 1$ 和 $\beta = \infty$ 分别对应符号 MAP 与码字 MAP。有限温度相图的定性特征也容易推广到任意无记忆信道；特别是，上述三相也可在这一一般情境下找到。解码在低噪声、大 β 相中成功。[6]

6.4 用随机码实现无错误通信

前面看到，用随机码和码字 MAP 在 BSC 上通信时，只要 $R < C_{\mathrm{BSC}}(p) = 1 - H_2(p)$，块错误率 P_B 就在大码长极限下趋零。这证明了 BSC 情形 Shannon 信道编码定理的“正向”部分：低于信道容量的速率可以实现无错误通信。结果实际一般得多。这里仍以随机码为基础，为一般无记忆信道给出证明。

为简单起见，只考虑二元输入、离散输出的无记忆信道，以转移概率 $Q(y \mid x)$ 定义，其中 $x \in \{0,1\}$、$y \in \mathcal{Y}$，$\mathcal{Y}$ 有限。为处理这一情形，需推广 RCE。每个码字 $x^{(m)} \in \{0,1\}^N$ $(m = 0, \ldots, 2^M - 1)$ 仍独立构造为 N 个独立同分布比特的序列，但每个比特 $x_i^{(m)}$ 不再均匀抽取，而是按任意分布 $P(x)$、$x \in \{0,1\}$ 抽取。须区分 $P(x)$ 与先验信源分布 $P_0(x)$：前者是定义码系综的任意单比特分布，可为优化性能而选择；后者是码字上的分布，模拟信息源的行为，参见式 (6.3)。与前几节一样，假设信源分布在码字上均匀，见式 (6.4)；但码字本身通过单比特分布 $P(x)$ 构造。

先分析一般 $P(x)$ 下采用码字 MAP 的 RCE，主要结果如下。

定理 6.1. *考虑转移概率 $Q(y \mid x)$ 的二元输入离散无记忆信道，使用输入比特分布为 $P(x)$ 的 RCE 中的码及码字 MAP 解码。若码率小于联合分布 $P(x)Q(y \mid x)$ 下随机变量 X, Y 间的互信息 $I_{X,Y}$，则块错误率在大码长极限下趋零。*

[5]这里定义的配分函数 $Z(\beta)$ 与 BSC 情形式 (6.25) 中的配分函数相差一个乘法常数。

[6]译注：$\beta \to \infty$ 与码字 MAP 的一致性仍需注意并列极大码字；任意退化信道并不自动具有三个非空相。原文定性推广照录，不作为所有信道的无条件相图定理。

由此可对 $P(\cdot)$ 优化系综性能。具体而言，最大化无错误通信可达速率的上限 $I_{X,Y}$。最优分布 $P^*(\cdot)$ 依赖信道，可视为与信道匹配。由于信道容量定义为输入和输出之间互信息的最大值，参见式 (1.37)，输入分布为 P^* 的 RCE 允许一直到信道容量的无错误通信。因此上述定理蕴含 Shannon 定理?? 的 "正向部分"。[7]

证明. 假设发送码字 $x^{(0)}$，接收消息 $y \in \mathcal{Y}^N$。解码器构造式 (6.3) 给出的条件分布。码字 MAP 解码等价于在码字 $x \in \mathcal{C}_N$ 上最小化代价

$$E(x) = -\sum_{i=1}^{N} \log_2 Q(y_i \mid x_i) \tag{6.28}$$

(注意这里使用自然对数)。当且仅当 $E(x)$ 的最小值由发送码字 $x^{(0)}$ 达到时，解码成功。因此问题归结为理解 2^M 个随机变量 $E(x^{(0)}), \ldots, E(x^{(2^M-1)})$ 的行为。

仍须单独处理 $E(x^{(0)})$。它是 N 个独立同分布变量 $-\log Q(y_i \mid x_i^{(0)})$ 之和，因此可由均值很好近似：

$$\mathbb{E}E(x^{(0)}) = -N \sum_{x,y} P(x)Q(y \mid x) \log_2 Q(y \mid x) = NH_{Y|X}. \tag{6.29}$$

特别地，$(1-\varepsilon)NH_{Y|X} < E(x^{(0)}) < (1+\varepsilon)NH_{Y|X}$ 在 $N \to \infty$ 时以趋于 1 的概率成立。

对于 $2^M - 1$ 个错误码字，对应的对数似然 $E(x^{(1)}), \ldots, E(x^{(2^M-1)})$ 独立同分布。因此可按已用于 REM 和 BSC 上 RCE 的方法估计其中最小值。附录 6.7 将证明这些变量分布的如下大偏差结果。

引理 6.2. 令 $\varepsilon_i = E(x^{(i)})/N$，则 $\varepsilon_1, \ldots, \varepsilon_{2^M-1}$ 独立同分布，其分布满足形如 $P(\varepsilon) \doteq 2^{-N\psi(\varepsilon)}$ 的大偏差原理。率函数为

$$\psi(\varepsilon) \equiv \min_{\{p_y(\cdot)\} \in \mathcal{P}_\varepsilon} \left[\sum_y Q(y) D(p_y \| P) \right], \tag{6.30}$$

最小化遍历分布集合 $\{p_y(\cdot) : y \in \mathcal{Y}\}$ 中满足约束

$$\varepsilon = -\sum_{x,y} Q(y) p_y(x) \log_2 Q(y \mid x) \tag{6.31}$$

的子空间 $\mathcal{P}_\varepsilon$，其中 $Q(y) \equiv \sum_x Q(y \mid x)P(x)$。

用标准 Lagrange 乘子法，可解此最小化问题：

$$p_y(x) = \frac{1}{z(y)} P(x) Q(y \mid x)^\gamma, \tag{6.32}$$

其中依赖 ε 的常数 $z(y)$ 和 γ 选为满足所有归一化 $\sum_x p_y(x) = 1$ 及约束 (6.31)。

率函数 $\psi(\varepsilon)$ 为凸函数，在 $\varepsilon_* = -\sum_{x,y} P(x)Q(y) \log_2 Q(y \mid x)$ 达到全局最小值 $\psi(\varepsilon_*) = 0$，对应 $\gamma = 0$。这意味着，以高概率，所有错误码字的代价 $E(x^{(i)}) = N\varepsilon$ 均在 $\varepsilon_{\min} \le \varepsilon \le \varepsilon_{\max}$ 范围内，其中两端是 $\psi(\varepsilon) = R$ 的两个解。此外，区间内任意 ε 附近满足 $E(x^{(i)}) \simeq N\varepsilon$ 的码字

[7]译注：这里及本章的 "无错误" 指码长趋于无穷时错误率趋零，不是有限码长零错误容量；一般能由该证明直接保证的是严格低于容量的固定速率。定理中的随机码性能还应明确对系综的平均或高概率意义。

数目指数级地多，实际上接近 $2^{NR-N\psi(\varepsilon)}$。最低代价错误码字的代价以高概率接近 $N\varepsilon_{\min}$。正确码字的代价则接近 $NH_{Y|X}$，因此最大似然解码以高概率找到它，当且仅当 $H_{Y|X}<\varepsilon_{\min}$。

条件 $H_{Y|X}<\varepsilon_{\min}$ 实际等价于 $R<I_{X,Y}$。简单计算表明，在式 (6.32) 中取 $\gamma=1$，便得到 $\varepsilon=H_{Y|X}$，从而 $p_y(x)=P(x)Q(y\mid x)/Q(y)$。率函数对应值为 $\psi(H_{Y|X})=H_Y-H_{Y|X}=I_{Y|X}$。因此无错误通信条件可重写为 $R<\psi(H_{Y|X})$，即 $R<I_{X,Y}$。 □

译注： 此处按原文保留几处不一致。式 (6.28)、(6.29) 明写 $\log_2$，正文却说自然对数；率函数和 R 以比特计时，D 也需采用相容底数。错误码字代价在固定输出 y 条件下独立；若对共享随机输出再平均，一般不能直接称无条件独立。率函数需先对典型输出条件化，零转移概率、退化信道、$\psi=R$ 无两个内部解及 $H_{Y|X}=0$ 等边界情形不由所写严格不等式证明涵盖。末行 $I_{Y|X}$ 按原记号保留，应与 $I_{X,Y}$ 对照；“附录 6.7” 实际是本章最后未编号附录，见下文。

例 6.3. *再考虑翻转概率 p 的 BSC。有*

$$E(x)=-(N-d(x,y))\log(1-p)-d(x,y)\log p. \tag{6.33}$$

除尺度因子外，该代价与到接收消息的 Hamming 距离一致。若取 $P(0)=P(1)=1/2$，由式 (6.32)，最优类型为

$$p_0(1)=1-p_0(0)=\frac{p^\gamma}{(1-p)^\gamma+p^\gamma}, \tag{6.34}$$

$p_1(x)$ 类似。相应代价为

$$\varepsilon=-(1-\delta)\log(1-p)-\delta\log p, \tag{6.35}$$

其中 $\delta=p^\gamma/[(1-p)^\gamma+p^\gamma]$。大偏差率函数的参数形式为 $\psi(\varepsilon)=\log 2-H(\delta)$。读者容易认出这就是上一节已得到的结果。

译注： 本例回到自然对数的写法，与引理中 $2^{-N\psi}$ 的比特率函数存在换底问题；保持原式，应用时须统一尺度。

习题 6.5. *考虑具有有限输入、输出字母表 $\mathcal{X},\mathcal{Y}$、转移概率 $Q(y\mid x)$ 的离散无记忆信道。检验上述证明在这一情境下仍成立。*

6.5 再谈几何：球堆积

编码与最优球堆积密切相关；后者是科学多个分支中备受关注的一般问题。例如考虑翻转概率 p 的 BSC。码率 R、码长 N 的码由超立方体 $\{0,1\}^N$ 中的 2^{NR} 个点 $\{x^{(1)},\dots,x^{(2^{NR})}\}$ 构成。解码器将每个可能输出 y 关联到某个码字，因此可视为把 Hamming 空间分成 2^{NR} 个判决区域 $\mathcal{D}^{(i)}$，每个区域对应一个不同码字。若要求每个判决区域包含一个半径 ρ 的球，则所得码保证能纠正翻转比特数少于 ρ 的任何错误模式。通常将任意两码字间的最小距离定义为码的最小距离。[8]若码的最小距离为 d，则半径 $\rho=\lfloor(d-1)/2\rfloor$ 的 Hamming 球不相交，该码可纠正任意位置的 ρ 个错误。

[8]不要与某一个给定码字到所有其他码字的最小距离混淆。

于是考虑超立方体 $\{0,1\}^N$ 上的一般球堆积问题。中心 x_0、半径 r 的 Hamming 球定义为满足 $d(x,x_0)\le r$ 的点集。一个半径 r、基数 $\mathcal{N}_S$ 的球堆积由中心 $x_1,\dots,x_{\mathcal{N}_S}$ 指定，各中心的半径 r 球两两不交。令 $\mathcal{N}_N^{\max}(\delta)$ 为半径 $N\delta$ 的球堆积的最大基数，定义对应速率 $R_N^{\max}(\delta)=N^{-1}\log_2\mathcal{N}_N^{\max}(\delta)$，希望在无穷维极限计算

$$R^{\max}(\delta)\equiv\limsup_{N\to\infty}R_N^{\max}(\delta). \tag{6.36}$$

确定 $R^{\max}(\delta)$ 是一个未解决的问题，只有上下界已知。这里推导最简单的两个界。

命题 6.4.

$$1-H_2(2\delta)\le R^{\max}(\delta)\le 1-H_2(\delta). \tag{6.37}$$

下界通常称为 Gilbert–Varshamov 界，上界称为 Hamming 界。

证明. 可以通过分析良好的堆积策略证明下界。一种简单策略是，在 Hamming 空间中均匀随机选择 2^{NR} 个点作为球心。任意两点间的距离须大于 $2N\delta$。定义计数距离为 d 的点对的距离枚举函数 $\mathcal{M}_2(d)$，可估计这一距离。当 $d=2N\delta$ 且固定 δ 取 $N\to\infty$ 时，容易证明

$$\mathbb{E}\mathcal{M}_2(d)=\binom{2^{NR}}{2}2^{-N}\binom{N}{d}\doteq 2^{N[2R-1+H_2(2\delta)]}. \tag{6.38}$$

只要 $R<[1-H_2(2\delta)]/2$，指数就为负。由 Markov 不等式，存在距离小于 2δ 的中心对的概率随规模指数级地小。因此

$$R^{\max}(\delta)\ge\frac{1}{2}[1-H_2(2\delta)]. \tag{6.39}$$

更仔细地考察上述随机堆积策略，可得到更好的下界。第 6.2 节证明：若在 Hamming 空间均匀选择 2^{NR} 个点，再选其中一个，它的最近邻距其以高概率接近 $N\delta_{\mathrm{GV}}(R)$。换言之，若以各点为心作半径 $\delta<\delta_{\mathrm{GV}}(R)/2$ 的球，再随机选一个球，则以高概率它不与任何其他球相交。这启发了一种技巧，编码理论中有时称为*删减*：依次检查每个球是否与其他球相交；若是，就将其删除。堆积基数因此减少，但删除的比例在 $N\to\infty$ 时趋零，故堆积速率不变。由于 $\delta_{\mathrm{GV}}(R)$ 定义为 $R=1-H_2(\delta_{\mathrm{GV}}(R))$，下界得证。

上界来自球占据的总体积不超过超立方体体积。以 $\Lambda_N(\delta)$ 表示半径 $N\delta$ 的 N 维 Hamming 球体积，则 $\mathcal{N}_S\Lambda_N(\delta)\le 2^N$。由于 $\Lambda_N(\delta)\doteq 2^{NH_2(\delta)}$，得到上界。 □

译注： 原文未写范围：上面的球体积指数适用于 $0\le\delta\le 1/2$；以 $H_2(2\delta)$ 表示的正码率 GV 下界需 $0\le\delta\le 1/4$，不能在 $\delta>1/4$ 继续按熵函数对称性延拓出正下界。半径和距离的整数取整也被省略。原文两处距离/半径写为 2δ、δ，作为实际 Hamming 距离应含 N，或明确采用归一化距离；这里保留原措辞并说明。

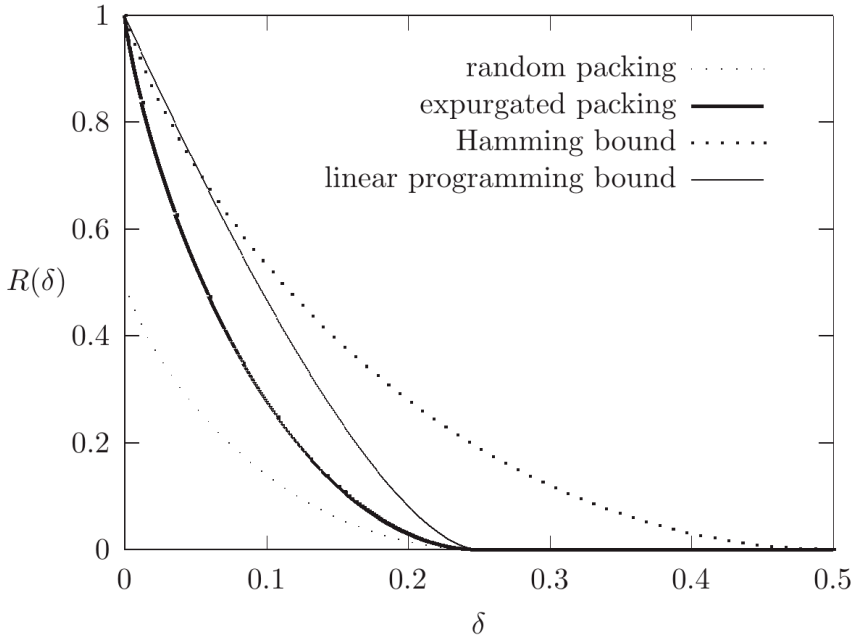


图 6.6: 半径 $N\delta$ 的 Hamming 球最大堆积速率 $R^{\max}(\delta)$ 的上下界。随机堆积和删减随机堆积给出下界，Hamming 界和线性规划界给出上界。取自 Part B PDF 第 31 页（原印刷 123）。

用更复杂的数学工具可导出更好的上界。其中一个重要结果是所谓*线性规划界*：

$$R^{\max}(\delta) \le H_2\left(\frac{1}{2} - \sqrt{2\delta(1-2\delta)}\right), \tag{6.40}$$

证明超出本书范围。另一方面，尚无比 Gilbert–Varshamov 结果更好的下界。一个广泛流传的猜想是该界实际上为紧界：在高维中，随机放置球并删去其中少数“受挤压”的球，就已是最好的堆积方式。图 6.6 汇总各界。[9]

习题 6.6. *按下列提示，为 Gilbert–Varshamov 界给出两个简单的替代证明。*

1. *给定常数 δ，考虑所有距离小于 $2N\delta$ 的“危险”点对。对每个危险点对，可删去其中一个点。删除点数不超过危险点对数，后者可用 $\mathbb{E}\mathcal{M}_2(d)$ 控制。使这一删减过程不降低码率的最大 δ 是多少？*

2. *如下构造堆积 $x_1, \dots, x_N$。第一个中心 x_1 可放在 $\{0,1\}^N$ 任意位置；第二个可放在以 x_0 为心、半径 $2N\delta$ 的球之外。一般地，第 i 个中心 x_i 可位于以 $x_1, \dots, x_{i-1}$ 为心的球之外任意位置。当半径 $2N\delta$ 的球覆盖整个 $\{0,1\}^N$ 时停止，得到半径 $N\delta$、基数 N 等于步数的堆积。*

译注：第二项原文把维数 N 同时用作最终中心数，且第二个球心写为未定义的 x_0；照录，不将其解释为堆积必须恰有 N 个球。

考察命题 6.4 对 BSC 编码的后果。若发送码字为 $x^{(i)}$，则信道输出以高概率距它约为 Np。显然，存在能纠正任意少于 Np 个比特翻转错误模式的 BSC 码，其充要条件是 $R \le R^{\max}(p)$。注意，

[9] 译注：这是作者 2007 年草稿中的知识状态和猜想，未核实其截至当前的进展；式 (6.40) 的通常非平凡适用区间也需结合 $\delta \le 1/4$ 等条件理解。

此纠错准则远强于要求比特或块错误率趋零。Shannon 定理正向部分保证：当 $R < 1-H_2(p) = C_{\mathrm{BSC}}(p)$ 时，存在块错误概率在 $N\to\infty$ 时趋零的码。如图 6.6 中线性规划界所示，p 足够大时 $C_{\mathrm{BSC}}(p)$ 高于 $R^{\max}(p)$。因此存在非空码率区间 $R^{\max}(p) < R < C_{\mathrm{BSC}}(p)$：可以以高概率纠正 Np 个错误，却不能纠正涉及这么多比特的任意错误模式。[10]

现在对 BSC 证明，要达到零块错误概率，条件 $R < 1-H_2(p)$ 实际也是必要的（即 Shannon 信道编码定理?? 的逆向部分）。定义 $P_B(k)$ 为信道恰翻转 k 比特条件下的块错误概率。若发送 $x^{(i)}$，输出位于以它为心、半径 k 的 Hamming 球边界 $\partial B_i(k) \equiv \{z : d(z,x^{(i)}) = k\}$。因此

$$P_B(k) = \frac{1}{2^{NR}}\sum_{i=1}^{2^{NR}}\left[1 - \frac{|\partial B_i(k)\cap \mathcal{D}^{(i)}|}{|\partial B_i(k)|}\right] \tag{6.41}$$

$$\geq 1 - \frac{1}{2^{NR}}\sum_{i=1}^{2^{NR}}\frac{|\mathcal{D}^{(i)}|}{|\partial B_i(k)|}. \tag{6.42}$$

由于 $\{\mathcal{D}^{(i)}\}$ 分割 $\{0,1\}^N$，$\sum_i |\mathcal{D}^{(i)}| = 2^N$。对于典型信道实现，$k$ 接近 Np，且 $|\partial B_i(Np)| \doteq 2^{NH_2(p)}$。由此推得，对任意 $\varepsilon > 0$ 和足够大的 N，

$$P_B \geq 1 - 2^{N(1-R-H_2(p)+\varepsilon)}, \tag{6.43}$$

所以可靠通信只有在 $R \leq 1 - H_2(p)$ 时才可能。[11]

6.6 其他随机码

随机码系综的一个主要缺点，是指定一个具体码（系综元素）需要 $N2^{NR}$ 比特。实践中使用码时，必须存储这些信息，很快就会超过硬件能力。*随机线性码*（RLC）系综可以紧凑得多：要求编码为线性映射，所有此类映射等概率。具体而言，码由 $N\times M$ 二元矩阵 $G = \{G_{ij}\}$（*生成矩阵*）完全指定，编码为左乘 G：

$$x : \{0,1\}^M \to \{0,1\}^N, \tag{6.44}$$

$$z \mapsto Gz, \tag{6.45}$$

其中乘法按模 2 进行。在线性码集合上赋予均匀概率，等价于假设 G 的元素独立同分布，$G_{ij} = 0,1$ 各以概率 $1/2$ 出现。指定一个系综元素只需 MN 比特。

习题 6.7. *考虑 $N = 4$、$|\mathcal{C}| = 8$ 的线性码*

$$\mathcal{C} = \{(z_1\oplus z_2, z_2\oplus z_3, z_1\oplus z_3, z_1\oplus z_2\oplus z_3) : z_1,z_2,z_3\in\{0,1\}\}, \tag{6.46}$$

其中 $\oplus$ 为模 2 相加。例如 $(0110)\in\mathcal{C}$，可取 $z_1=1,z_2=1,z_3=0$，但 $(0010)\notin\mathcal{C}$。计算相对于 $x_0 = (0110)$ 的距离枚举函数。

---

[10]译注：$R^{\max}$ 用 $\limsup$ 定义，边界 $R = R^{\max}(p)$ 的可达性、每个足够大码长还是某个子序列，以及取整和少于/不超过的区别，均需另行精确表述；原文的闭区间“充要”措辞照录。

[11]译注：本段开头写严格小于，最终只推出小于等于；不将二者混同。由典型噪声层转为无条件错误率，通常还需保留典型事件之外的概率修正；式 (6.43) 按草稿保留，不将其所写有限 N 精确形式视为已补齐的严格界。

RLC 的性能极好。与原始 Shannon 系综一样，它允许在容量以下无错误通信；而且块错误概率 P_B 趋零的速率比 RCE 更快。因此，人们付出了大量努力，设计和分析同时满足额外计算要求的特定线性码系综。后续章节将讨论其中一些最好的系综。[12]

6.7 关于编码理论与无序系统的说明

强调一下，随机码系综分析与无序系统统计物理之间有根本相似性。如前面应已说明的，编码中有多个随机性来源。

- 首先，从某个系综随机选择所用码。这是 Shannon 证明信道编码定理的原始思想。
- 从码中按均匀概率选择待传码字。这一假设得到信源—信道分离定理支持。
- 给定发送码字，信道输出按描述信道噪声的概率过程分布。
- 给定上述各项，还需解决解码问题。如第 6.3.3 节所述，经典 MAP 和有限温度解码可以统一定义：解码器在可能的信道输入上构造 $P_\beta(x)$，估计其单比特边缘 $P_\beta^{(i)}(x_i)$，第 i 比特的决定依赖于此分布。

因此，分析某个编码系统，可视为当码、发送码字和噪声实现按上述方式分布时，分析分布 $P_\beta(x)$ 的性质。

换言之，区分了两层随机性：[13]第一层处理前三种随机性来源，第二层使用分布 $P_\beta(x)$。此时与无序系统理论的深刻类比应已清楚：码、信道输入和噪声实现扮演淬火无序（样本）的角色，$P_\beta(x)$ 则类似 Boltzmann 分布。两者都研究一个本身也是随机对象的概率分布的性质。

注释

随机码系综可追溯至 Shannon（Shannon, 1948），他在信道编码定理证明中以某种隐含方式使用了它。Gallager 给出更明确且完整的证明（Gallager, 1965）。其他证明可见标准教科书，如 Cover 和 Thomas（Cover and Thomas, 1991）、Csiszár 和 Körner（Csiszár and Körner, 1981）、Gallager（Gallager, 1968）。

距离枚举函数在编码理论中有广泛研究，例如可参阅 Csiszár 和 Körner（1981）以及 Gallager（1968）。Montanari（Montanari, 2001）以类比 REM 的方式处理随机码系综。同一思路下更细致的结果可参阅 Barg 和 G. David Forney（Barg and G. David Forney, 2002）。Sourlas 提出了编码理论与无序系统统计物理的类比（Sourlas, 1989）。有限温度解码由 Rujan 提出（Rujan, 1993）。

分析中的一个关键因素，是第 1.6.2 节已提及的假设：每个码字先验等概率。这一假设的根本依据是信源—信道分离定理。简单地说，将编码系统分成两个部分不会造成损失：信源码

[12]译注：随机矩阵未必满列秩，均匀线性映射与均匀选择固定维数不同子空间也不是完全同一有限规模系综；本段性能比较须明确所用信道及误差指数范围，不能由前述一般非对称信道容量结论无条件推出。原文断言保留，未在本轮独立认证。

[13]这一观点还可细分。例如，码不太可能在每次使用信道时改变，而码字和噪声实现则肯定改变。处理有限码长效应时，这一点尤其重要。

先压缩信息源产生的数据，输出独立同分布的无偏比特序列；信道码再为它增加冗余，以对抗信道噪声。纠错码理论和本章都着重设计、分析第二部分，把第一部分交给信源编码。分离定理证明可见 Cover 和 Thomas（1991）、Csiszár 和 Körner（1981）以及 Gallager（1968）。[14]

球堆积是数学中的经典问题，在多个科学分支中有应用。Conway 和 Sloane 的著作（Conway and Sloane, 1998）既给出良好入门，也包含该问题及其与编码理论等联系的深刻结果。对于 $n \geq 4$，寻找 $\mathbb{R}^n$ 中最密球堆积是未解决问题。[15]

附录：引理 6.2 的证明

估计某个错误码字 x 具有代价 $E(x) = N\varepsilon$ 的概率 $P_N(\varepsilon)$，取大 N 极限下的主导指数阶。信道输出 $y = (y_1, \ldots, y_N)$ 是 N 个独立同分布符号的序列，其分布为

$$Q(y) \equiv \sum_x Q(y \mid x) P(x), \tag{6.47}$$

代价可重写为

$$\begin{aligned} E(x) &\equiv -\sum_{i=1}^{N} \log Q(y_i \mid x_i) \\ &= -N \sum_{x,y} Q(y) \log Q(y \mid x) \frac{1}{NQ(y)} \sum_{i=1}^{N} \mathbf{1}(x_i = x, y_i = y). \end{aligned} \tag{6.48}$$

对每个 $y \in \mathcal{Y}$，满足 $y_i = y$ 的位置约有 $NQ(y)$ 个。假设恰有这么多个位置，且 $NQ(y)$ 为整数。当然此假设一般不成立；*略作技术处理即可避免，细节留给读者作为常规习题。此外，引入

$$p_y(x) \equiv \frac{1}{NQ(y)} \sum_{i=1}^{N} \mathbf{1}(x_i = x, y_i = y). \tag{6.49}$$

在上述假设下，对每个 y，函数 $p_y(x)$ 都是 $x \in \{0, 1\}$ 上的概率分布。考虑满足 $y_i = y$ 的位置子序列，它计数其中 $x_i = x$ 的比例。换言之，$p_y(\cdot)$ 是子序列 $\{x_i : y_i = y\}$ 的类型。由式 (6.48)，代价表示为

$$E(x) = -N \sum_{x,y} Q(y) p_y(x) \log Q(y \mid x). \tag{6.50}$$

因此，$E(x)$ 仅通过类型 $\{p_y(\cdot) : y \in \mathcal{Y}\}$ 依赖于 x，且对 $p_y(x)$ 线性。按 RCE 定义，$x_1, \ldots, x_N$ 是分布为 $P(x)$ 的独立同分布变量。由推论 4.5 可推出 $E(x)/N = \varepsilon$ 的概率。在主导指数阶，得到

$$P(\varepsilon) \doteq \exp\{-N\psi(\varepsilon) \log 2\}, \tag{6.51}$$

$$\psi(\varepsilon) \equiv \min_{p_y(\cdot)} \left[\sum_y Q(y) D(p_y \| P) \text{ 满足 } \varepsilon = -\sum_{x,y} Q(y) p_y(x) \log_2 Q(y \mid x) \right]. \tag{6.52}$$

[14]译注：这里是分离思想的渐近说明；一般有限块信源压缩不自动输出严格独立、严格无偏的比特。

[15]译注：这是原 2007 年草稿的历史性陈述，不能当作当前知识状态；例如特定维数可能已有后续严格结果，本轮未作最新文献核验。可唯一匹配的作者—年份条目已连至书目，其余见书后说明。

译注：这一定型计算应理解为固定典型输出后对错误码字的条件大偏差；若要无条件平均，还要控制输出类型的涨落。原稿在代价定义和最后约束中混用 $\log$ 与 $\log_2$，不静默统一。$Q(y)=0$ 的输出符号应排除或单独约定，以避免除零；当 $Q(y\mid x)=0$ 时对数及支集也需限制。原文“附录 6.7”与本未编号附录的关系及所有作者—年份引文尚待最终统一核查。

第七章　数字划分

数字划分是最基本的优化问题之一，表述十分简单：“给定 N 项资产的价值，能否将它们公平地分成两组？”然而它很难求解：它属于 NP 完全问题，已知启发式方法往往也不太好。此外它还有实际应用，例如多处理器调度。

本章特别关注独立同分布随机数列表的划分。大多数启发式方法在这一实例系综上表现不佳，因此可用它检验新算法，也有必要分析它。另一方面，随机实例的结构相对容易解析刻画。主要结果是：低代价构型，即两组之和差异很小的构型，可视作独立能级；模型的行为与第 五章的随机能量模型十分相似。

7.1　公平地分成两组？

数字划分问题的一个实例，是 N 个正整数组成的集合 $S = \{a_1, \ldots, a_N\}$，以 $i \in [N] \equiv \{1, \ldots, N\}$ 编号。希望将它们分为 $\{a_i : i \in \mathcal{A}\}$ 和 $\{a_i : i \in \mathcal{B} \equiv [N] \setminus \mathcal{A}\}$，使两个子集中元素之和的差最小。换言之，构型由 $\mathcal{A} \subseteq [N]$ 给定，代价定义为

$$E_{\mathcal{A}} = \left| \left(\sum_{i \in \mathcal{A}} a_i \right) - \left(\sum_{i \in \mathcal{B}} a_i \right) \right|. \tag{7.1}$$

完美划分是两子集中的总和尽量相等，即 $E_{\mathcal{A}} \leq 1$：若 $\sum_i a_i$ 为偶数则 $E_{\mathcal{A}} = 0$，为奇数则 $E_{\mathcal{A}} = 1$。通常可定义多个版本，包括：

1. 判定问题：是否存在完美划分？
2. 优化问题：找到代价最低的划分。

问题还有多种变体。至此未限制 $\mathcal{A}$ 的大小，这称为无约束版本；也可研究有约束版本，要求两子集的基数差 $|\mathcal{A}| - |\mathcal{B}|$ 固定为某数 D。为简单起见，这里主要讨论无约束情形。

习题 7.1. *作为热身，读者可证明以下结论，必要时编写简单的穷举程序。*

- $S_1 = \{10, 13, 23, 6, 20\}$ *存在完美划分。*
- $S_2 = \{6, 4, 9, 14, 12, 3, 15, 15\}$ *存在完美平衡划分。*
- $S_3 = \{93, 58, 141, 209, 179, 48, 225, 228\}$ *的最低代价为 5。*
- $S_4 = \{2474, 1129, 1388, 3752, 821, 2082, 201, 739\}$ *的最低代价为 48。*

译注：各 a_i 按指标区分，即使数值相等也为两个项目；因此原文的“集合”按带标号列表理解。“平衡”指两组元素数相同。上述四条已用有限穷举核对；S_4 的无约束最低代价 48 不等于其平衡划分最低代价 262。

7.2 算法问题

7.2.1 一个 NP 完全问题

要理解问题的复杂度，先须衡量规模，即指定一个实例所需的字符数。数字划分中，这关键地取决于整数能有多大。假设限制为

$$a_i \in \{1, \ldots, 2^M\} \qquad \forall i \in \{1, \ldots, N\}, \tag{7.2}$$

每个整数可用 M 比特编码，整个实例用 NM 比特。目前没有已知算法能在某个 NM 的幂为上界的时间内求解数字划分。对无界整数（任意 M），穷举显然可在 2^N 次操作中找到解。*对有界整数，有时间量级 $N^2 2^M$ 的简单算法：提示是考察 1 到 $N2^M$ 的全部整数，递归找出哪些可由列表中前 k 个数相加得到。事实上，数字划分属于 NP 完全类，甚至被视为这一类中的基本问题。[1]

7.2.2 简单启发式与完备算法

数字划分没有好的算法。Karmarkar 和 Karp（KK）提出的一种最佳启发式方法采用如下思路。从原整数列表 $a_1, \ldots, a_N$ 出发，删除其中两个元素 a_i, a_j，若差非零，则用 $|a_i - a_j|$ 替换它们。这意味着已决定把两者放入不同子集，但不指定各在哪组。只要列表至少含两个元素，就继续操作。若最终得到空列表或 $\{1\}$，便存在完美划分；否则剩下的整数是某个划分的代价，但可能还有更好的解。每一步如何选择两个元素，有很大的灵活性，需要巧思。KK 算法每次选最大的两个数。

例 7.1. *看习题 7.1 首个列表 $\{10, 13, 23, 6, 20\}$。第一步用 3 替换 23 和 20，得到 $\{10, 13, 6, 3\}$。随后依次得到 $\{3, 6, 3\}$、$\{3, 3\}$、$\varnothing$，说明存在完美划分。读者可思考如何系统地重建这一划分。*

Korf 的修改将 KK 启发式变为完备算法，最终会返回最佳划分，尽管可能耗费指数时间。每次消去 a_i, a_j 时构造两个新列表：“左” 列表含 $|a_i - a_j|$，对应把两者放在不同组；右列表含 $a_i + a_j$，对应放在同组。迭代构造一棵有 2^{N-1} 个叶节点的树，每个叶节点包含一个合法划分的代价。反过来，每个可能划分的代价都在某个叶节点出现；注意 2^N 个可能的 $\mathcal{A}$ 中，每个都与补集 $[N] \setminus \mathcal{A}$ 等价。若只关心 “是否存在完美划分”，可剪枝：当某个列表的最大元素超过其余元素之和再加 1 时，这一列表不可能导出完美划分，可不再构造以它为根的子树。图 7.1 给出简单例子。

[1]译注：NP 完全对应判定版本；优化版本通常表述为 NP 困难。操作次数还取决于整数算术模型；$\{1, \ldots, 2^M\}$ 可通过编码 $a_i - 1$ 用 M 比特表示。原文 “没有已知算法” 是知识状态，不是证明不存在多项式算法。

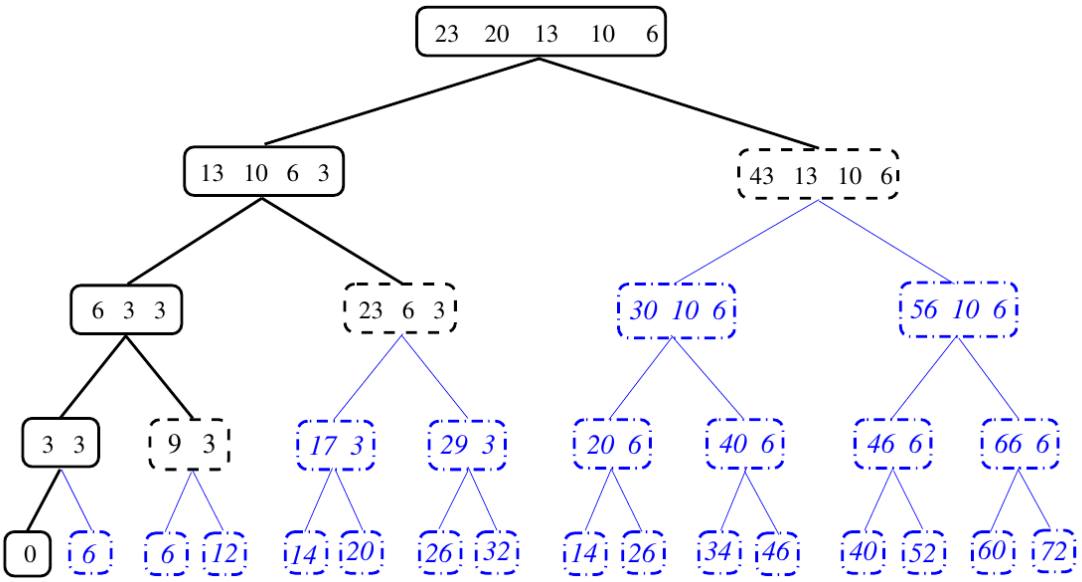


图 7.1: 完备搜索算法。从列表删除最大的 a_i, a_j，生成两个新列表：左边含 $|a_i - a_j|$，右边含 $a_i + a_j$。每个叶节点都包含一个合法划分的代价。搜索完美划分时，可在虚线框节点剪枝，因为最大数大于其他数之和；点划线框的列表不生成。KK 只选左分支，本例成功找到唯一完美划分。取自 Part B PDF 第 39 页（原印刷 131）。

译注：图注的剪枝阈值没有写正文中的“加 1”；总和奇数、允许代价 1 时须采用与完美划分定义相容的阈值。若差为 0 时直接删去两项，实际生成树未必恰有 2^{N-1} 个不同叶；此为未合并退化分支时的完全二叉计数。

7.3 随机列表划分：实验

生成随机实例的一种自然方法，是独立同分布地选取 N 个输入数。这里取 a_i 在 $\{1, \dots, 2^M\}$ 上均匀分布。如第 3 章所述，可用随机实例检验算法的典型性能；也关心 $N, M \to \infty$ 时最优代价分布等自然的概率问题。

先直观理解 N（列表大小）和 M（每个 a_i 的二进制位数）的不同作用。考虑例 1 中的 S_2, S_3, S_4；每个都含 $N = 8$ 个随机数，分别以 $M = 4, 8, 16$ 生成。M 越大，a_i 的典型值越大，公平分配越难。考察所有划分的代价，合理地预期约一半划分的最高有效位为 0，其中约一半的第二高位也为 0。划分数为 2^{N-1}，因此可大致迭代这一论证 N 次。于是预期，大 N 随机实例在 $N > M$ 时有显著机会存在完美划分；相反，$N < M$ 时最优划分的典型代价应如 2^{M-N}。[2]

对于 N, M 的主导指数行为，这一直观推理基本正确。先给出较小系统的数值证据，用第 7.2.2 节的完备算法得到，下一节再以更精确的解析论证验证。

图 7.2 数值估计随机实例存在完美划分的概率 $p_{\text{perf}}(N, M)$ 随 N 的变化。对每个 N, M 抽取 n_{stat} 个实例并逐一穷举求解；$M = 8, 16, 24$ 时分别取 $n_{\text{stat}} = 10000, 1000, 100$。有完美划分

[2]译注：原文“例 1”实际对应习题 7.1。此处 S_4 中的数都小于 2^{12}，原文声称其用 $M = 16$ 生成；仅从所列样本不能验证生成分布，照录作者描述。

的样本比例用于估计概率，标准差为 $\sqrt{p_{\mathrm{perf}}(1-p_{\mathrm{perf}})/n_{\mathrm{stat}}}$。

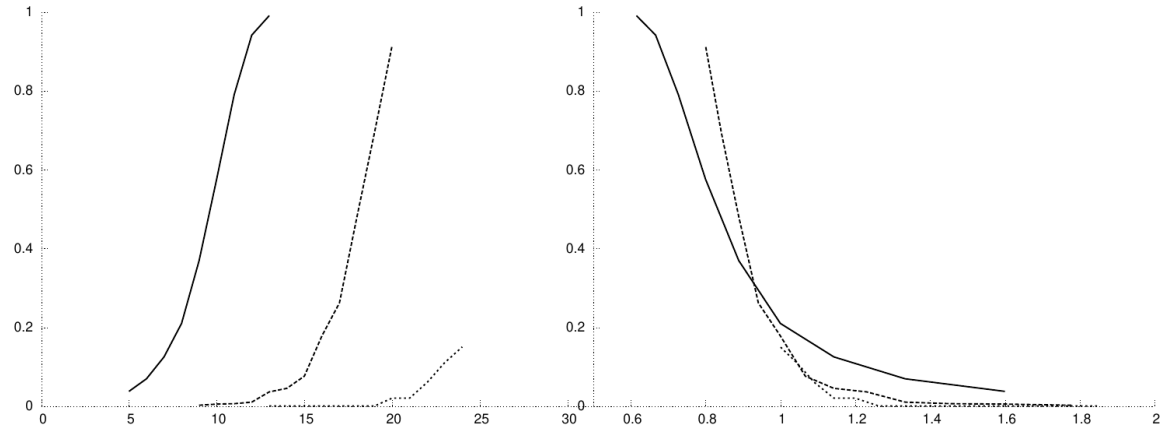


图 7.2: 随机生成数集的数值研究：a_i 均匀分布于 $\{1,\ldots,2^M\}$，且 $\sum_i a_i$ 为偶数。存在完美平衡划分的样本比例随 N（左，从左到右为 $M=8,16,24$）及 $\kappa=M/N$（右）的变化。固定 κ 取 $N\to\infty$ 时，概率变为阶跃：$\kappa<1$ 时为 1，$\kappa>1$ 时为 0，亦见图 7.4。取自 Part B PDF 第 40 页（原印刷 132）。

固定 M 时，p_{perf} 从小 N 时接近 0，交叉过渡到大 N 时接近 1，过渡位置似与 M 成正比。定义比值

$$\kappa = M/N, \tag{7.3}$$

将 p_{perf} 视为 N,κ 的函数，可以换个角度看数据。图 7.2 右图在固定 N 下画 $p_{\mathrm{perf}}(\kappa,N)$，行为很有趣。仔细分析数值数据[3]表明，$\lim_{N\to\infty} p_{\mathrm{perf}}(\kappa,N)$ 在 $\kappa<1$ 时为 1，在 $\kappa>1$ 时为 0。强调一下：固定 κ 取 $N\to\infty$，因此 M 也与 N 成比例趋于无穷。

这是第 2 章意义下的典型相变。当控制参数穿越临界值 $\kappa_c=1$ 时，一般大实例的行为完全改变：$\kappa<1$ 时几乎所有实例有完美划分，$\kappa>1$ 时几乎都没有。这对计算难度有重要影响。衡量 Korf 完备算法性能的良好指标，是找到最优划分前生成的列表数 R。

[3]分析时，随机代价模型或后文精确结果的指引很有用。

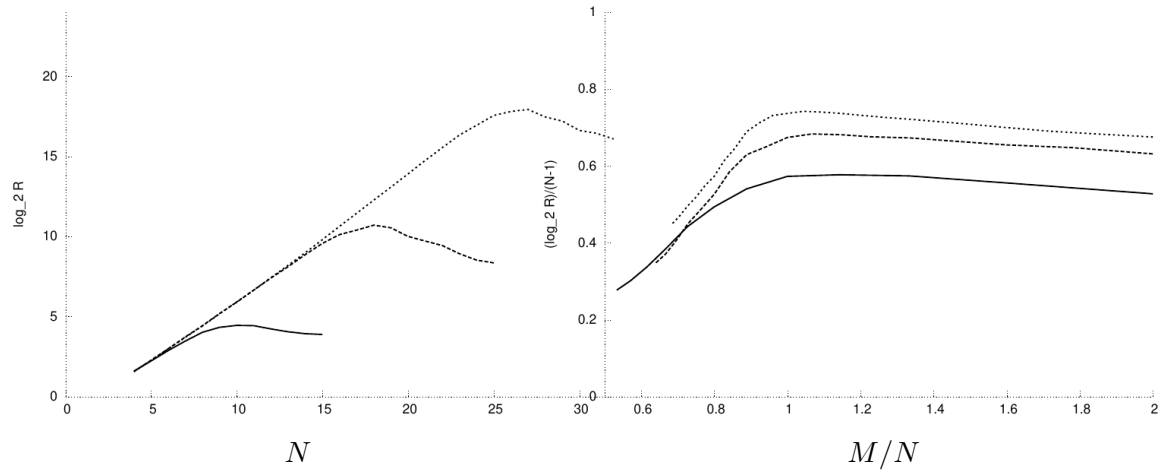


图 7.3: 左：$\log_2 R$ 的平均值，R 为搜索树大小。三曲线从左到右对应 $M = 8, 16, 24$；大小随 N 指数增长，在 $N \approx M$ 附近达到峰值。右：平均 $\log_2 R/(N-1)$ 随 $\kappa = M/N$ 的变化。取自 Part B PDF 第 41 页（原印刷 133）。

图 7.3 使用与图 7.2 相同实例，对 $\log_2 R$ 取平均。搜索树先随 N 指数增长，再在 $N \approx M$ 附近达到峰值。按 κ 作图时，可见 $\kappa_c = 1$ 附近的清晰峰：临界点附近的问题对所考虑算法最难。其他算法也有类似行为，后文还将在可满足性、着色等判定问题中遇到。当随机实例类随某参数发生相变时，最难实例一般位于相变附近。[4]

7.4 随机代价模型

7.4.1 模型定义

仍考虑 a_j 独立均匀分布于 $\{1, \ldots, 2^M\}$ 生成的随机实例。给定划分 $\mathcal{A}$，代价 $E_{\mathcal{A}}$ 是分布为 $\mathcal{P}_{\mathcal{A}}$ 的随机变量。显然，不同划分的代价相关。随机代价近似忽略这些相关性。任何问题都可作这种近似，但未必好。值得注意的是，Mertens 发现，对独立同分布随机数的划分，这一近似“本质上精确”。

为精确陈述，定义类似 REM 的随机代价模型（RCM）。一个样本由全部 2^{N-1} 个“划分”的代价给定，这里将互补划分认作同一个。假设这些代价是从分布 $\mathcal{P}$ 抽取的独立同分布变量。为模拟原数字划分，取 $\mathcal{P}$ 与原问题随机划分的代价分布相同：

$$\mathcal{P} \equiv \frac{1}{2^{N-1}} \sum_{\mathcal{A}} \mathcal{P}_{\mathcal{A}}. \tag{7.4}$$

求和遍历互补等价类，$\mathcal{P}_{\mathcal{A}}$ 为原问题特定划分的代价分布。

分析大 N 下的 $\mathcal{P}$。原问题随机划分的代价为 $|\sum_i \sigma_i a_i|$，其中 $\sigma_i = \pm 1$ 独立且各以概率 $1/2$ 取值。大 N 时，中心极限定理刻画 $\sum_i \sigma_i a_i$ 的分布，限制到正半轴得到 $\mathcal{P}$。特别地，代价以高概率具有量级 $\sqrt{N\alpha_M^2}$，其中

$$\alpha_M^2 \equiv \mathbb{E}a^2 = \frac{1}{3}\,2^{2M} + \frac{1}{2}\,2^M + \frac{1}{6}. \tag{7.5}$$

[4]译注：这是作者对所研究实例和算法的经验描述，不是全部相变与全部算法的复杂度定理。图 7.2 图注称“平衡”划分，本节文字与后文 RCM 主要为无约束划分，两者不可不加区分地混用有限尺寸结果。

且对于任意 $0 \le x_1 < x_2$，

$$\mathcal{P}\left(\frac{E}{\sqrt{N\alpha_M^2}} \in [x_1, x_2] \right) \simeq \sqrt{\frac{2}{\pi}} \int_{x_1}^{x_2} e^{-x^2/2}\, dx.$$

最后，完美划分概率 $\mathcal{P}(E=0)$ 就是步长 $\sigma_i a_i \in \{-2^M, \dots, -1\} \cup \{1, \dots, 2^M\}$ 的随机游走返回原点的概率。为简单起见，假设 $\sum_i a_i$ 为偶数，则

$$\mathcal{P}(0) \simeq \frac{2}{\sqrt{2\pi N\alpha_M^2}} \simeq \sqrt{\frac{6}{\pi N}}\, 2^{-M}. \tag{7.6}$$

其中 $1/\sqrt{2\pi N\alpha_M^2}$ 是均值 0、方差 $N\alpha_M^2$ 的正态变量在原点附近的密度；额外因子 2 来自随机游走仅能到达偶数的事实。后文将看到，RCM 很好近似原问题。下面习题给出一些直观依据。

习题 7.2. *考虑两个均匀随机、相互独立的划分 $\mathcal{A}, \mathcal{A}'$。令 $\mathcal{P}(E, E')$ 为其能量联合概率，$\{a_i\}$ 独立均匀分布于 $\{1, \dots, 2^M\}$。证明在大 N, M 极限下，若 $E, E' < C2^M$、C 固定，则 $\mathcal{P}(E, E') = \mathcal{P}(E)\mathcal{P}(E')[1 + o(1)]$。*

译注： 离散代价的共同奇偶性由同一 $\sum_i a_i$ 决定，且两个随机划分可能互补或重合。所写相对误差结论需要明确奇偶条件、能量取值与 N, M 联合极限；不能只靠中心极限定理无条件推出所有小代价尺度上的独立性。

7.4.2 相变

先确定 RCM 相变，再研究通常没有完美划分的 $\kappa > 1$ 相，以及存在指数多个完美划分的 $\kappa < 1$ 相。随机 RCM 实例没有完美划分，等价于每个划分代价严格正。由于 2^{N-1} 个代价独立同分布，

$$1 - p_{\mathrm{perf}}(\kappa, N) = [1 - \mathcal{P}(0)]^{2^{N-1}}. \tag{7.7}$$

固定 κ 的大 N 极限下，式 (7.6) 给出 $\mathcal{P}(0) \ll 1$，因而

$$\begin{aligned} p_{\mathrm{perf}}(\kappa, N) &= 1 - \exp[-2^{N-1}\mathcal{P}(0)] + o(1) \\ &= 1 - \exp\left[-\sqrt{\frac{3}{2\pi N}}\, 2^{N(1-\kappa)} \right] + o(1). \end{aligned} \tag{7.8}$$

这预测 RCM 在 $\kappa_c = 1$ 发生相变：$\kappa < 1$ 时极限概率为 1，$\kappa > 1$ 时为 0。它还描述有限 N 下临界点附近的精细行为。定义 $x = N(\kappa - \kappa_c) + (1/2)\log_2 N$，在固定 x 时取 $N \to \infty$、$\kappa \to \kappa_c$，得到交叉过渡

$$\lim_{\substack{N\to\infty \\ \kappa\to\kappa_c}} p_{\mathrm{perf}}(\kappa, N) = 1 - \exp\left[-\sqrt{\frac{3}{2\pi}}\, 2^{-x} \right]. \tag{7.9}$$

这是有限尺寸标度的一个例子。

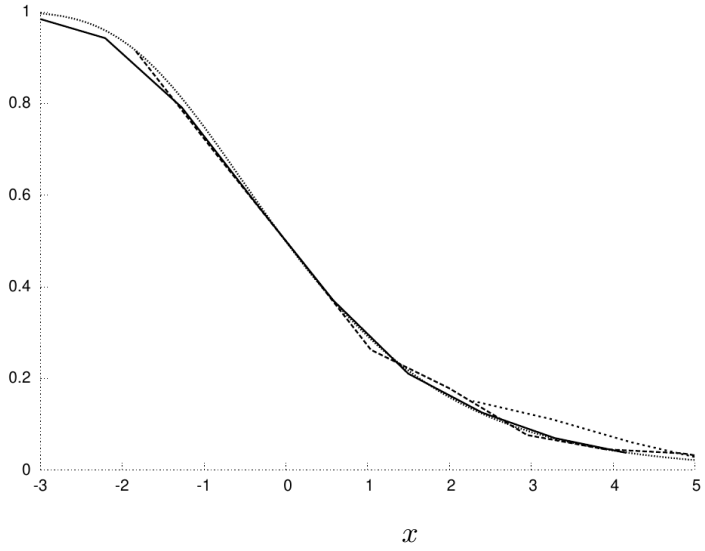


图 7.4: 将图 7.2 的数据重绘，展示估计的完美划分概率 $p_{\mathrm{perf}}(N,M)$ 随缩放变量 $x = N(\kappa - \kappa_c) + (1/2)\log_2 N$ 的变化。与理论预测 (7.9) 很好吻合。译注：原横轴标签与图注靠近，此处将绘图区裁切并以 TeX 补排原标签 x。取自 Part B PDF 第 44 页（原印刷 136）。

图 7.4 将原问题数值结果与预测比较，使用相同数据，只把横轴从 N 改为 x。不同 M 曲线的良好塌缩，为数字划分渐近等价于 RCM、并在 $\kappa = 1$ 相变的说法提供证据。

习题 7.3. 上述论证假设 $\sum_i a_i$ 为偶数，图 7.4 的模拟也施加此条件。若总和为奇数，应如何修改式 (7.6) 中 $\mathcal{P}(0)$ 的估计？证明保持 $x = N(\kappa - \kappa_c) + (1/2)\log_2 N$ 的定义时，标度函数变为 $1 - \exp[-2\sqrt{3/(2\pi)}\,2^{-x}]$。运行模拟检验这一预测。

译注： 奇数总和时完美代价是 1，严格零代价概率为 0；原文要求 “修改 $\mathcal{P}(0)$” 应与 $\mathcal{P}(1)$ 区分，原意为完美划分事件概率。此处保留原问题，不声称已完成所要求的新模拟。

7.4.3 两个相的研究

考察 $\kappa > 1$ 相的最低代价。所有构型代价大于 E 的概率为

$$\mathbb{P}(\forall \mathcal{A} : E_{\mathcal{A}} > E) = \left(1 - \sum_{E'=0}^{E} \mathcal{P}(E')\right)^{2^{N-1}} . \tag{7.10}$$

当 $\sum_{E'=0}^{E} \mathcal{P}(E') = O(2^{-N})$ 时，此概率非平凡，即不为 0 或 1。容易证明，可将和中的 $\mathcal{P}(E')$ 替为 $\mathcal{P}(0)$ 来估计，得到 $E \sim 1/[\mathcal{P}(0)2^{N-1}] \sim 2^{M-N}\sqrt{N}$。[5]由此得到

$$\lim_{N\to\infty} \mathbb{P}\left(\forall \mathcal{A} : E_{\mathcal{A}} > \frac{\varepsilon}{\mathcal{P}(0)2^{N-1}}\right) = e^{-\varepsilon}\mathbf{1}(\varepsilon \geq 0). \tag{7.11}$$

特别地，右侧分布的均值为 1，因此最低代价期望为 $\mathbb{E}E_{\mathrm{gs}} = \sqrt{2\pi N/3}\,2^{N(\kappa-1)}$。这些预测与数字划分数值结果也很好吻合。[6]

[5]所得 E 远小于 $\mathcal{P}(E)$ 显著变化的尺度，参见式 (7.6)，因此这一替换自洽。

[6]译注：式 (7.11) 左侧是生存概率，对 $\varepsilon < 0$ 应为 1，原右侧示性函数使其为 0；在所讨论 $\varepsilon \geq 0$ 上保留该表达式。对于偶数总和，正偶数代价的绝对值简并度与零代价不同，奇数代价无权重，替换离散概率时应同时处理这两点。均值公式是大 N 预测，不是有限规模精确等式。

习题 7.4. 证明第 k 小代价构型在缩放变量 ε 中的概率密度为 $\varepsilon^{k-1}e^{-\varepsilon}\mathbf{1}(\varepsilon>0)/(k-1)!$。这是有界独立同分布变量极值统计的典型例子。

$\kappa<1$ 时，几乎所有样本至少有一个零代价构型。计数零代价构型数也有启发性。每个构型独立地以概率 $\mathcal{P}(0)$ 为零，因此其数目 Z 为二项变量：

$$\mathbb{P}(Z)=\binom{2^{N-1}}{Z}\mathcal{P}(0)^{Z}[1-\mathcal{P}(0)]^{2^{N-1}-Z}. \tag{7.12}$$

大 N 时，Z 集中在其均值 $Z_{\mathrm{av}}\doteq 2^{N(1-\kappa)}$ 附近。定义基态熵密度

$$s_{\mathrm{gs}}=\frac{1}{N}\log_2 Z. \tag{7.13}$$

RCM 预测，$\kappa<1$ 时熵密度以高概率接近 $1-\kappa$。原数字划分数值模拟也证实这一预期。

习题 7.5. 使用对数的积分表示

$$\log_2 x=\int_0^\infty\frac{dt}{t}\left(e^{-t\log 2}-e^{-tx}\right), \tag{7.14}$$

直接计算 $\mathbb{E}s_{\mathrm{gs}}$。注意 t 积分由量级 $1/[2^{N-1}\mathcal{P}(0)]$ 的极小 t 主导，于是容易得到

$$\mathbb{E}s_{\mathrm{gs}}\simeq N^{-1}\log_2[2^{N-1}\mathcal{P}(0)]\simeq 1-\kappa.$$

译注：原积分右侧按 Frullani 公式为 $\log(x/\log 2)$，并非 $\log_2 x$；相容表示应为 $(\log 2)^{-1}\int_0^\infty(e^{-t}-e^{-tx})dt/t$。另外有限 N 时二项模型有正概率 $Z=0$，故不加条件的 $\mathbb{E}\log Z$ 为 $-\infty$；高概率典型熵或条件于 $Z>0$ 的期望须与原无条件表达式区分。原习题保留。

7.5 随机列表划分：严格结果

Borgs、Chayes 和 Pittel 已严格细致地刻画随机数划分的相图，基本证实了 RCM 预测。先陈述已知的 N 个数平衡划分的若干精确结果。为明确起见，仍取 a_i 独立均匀分布于 $\{1,\dots,2^M\}$，且 N 与 $\sum_{i=1}^N a_i$ 都为偶数。以下结果在固定 $\kappa=M/N$、$N,M\to\infty$ 的“热力学极限”成立。

定理 7.2. 在 $\kappa=1$ 存在相变。$\kappa<1$ 时，随机实例以高概率有完美平衡划分；$\kappa>1$ 时，以高概率没有完美平衡划分。

定理 7.3. $\kappa<1$ 相中，完美平衡划分数的熵密度 (7.13) 依概率收敛到 $s=1-\kappa$。

定理 7.4. 定义 $\overline{E}=2^{N(\kappa-1)}\sqrt{2\pi N/3}$，令 $E_1\le\cdots\le E_k$ 为固定 k 个最低代价。则 k 元组 $(\varepsilon_1=E_1/\overline{E},\dots,\varepsilon_k=E_k/\overline{E})$ 依分布收敛到 $(W_1,W_1+W_2,\dots,W_1+\cdots+W_k)$，其中 W_i 独立同分布，分布为 $P(W_i)=e^{-W_i}\mathbf{1}(W_i\ge 0)$。特别地，缩放后的最优代价分布收敛到 $P(\varepsilon_1)=e^{-\varepsilon_1}\mathbf{1}(\varepsilon_1\ge 0)$。

这些结果都与 RCM 一致。特别地，定理 7.4 说明，固定 k 而令 $N\to\infty$ 时，最低的 k 个代价是独立同分布变量，正如 RCM 的假设。这解释了随机代价近似为何如此好。**译注：**以上按草稿原文保留，但有实质问题。最低的有序代价是指数变量的累积和，独立的是相邻间隔 W_i，而不是有序代价本身。原文在平衡划分背景下给出的 $\sqrt{N}\,2^{M-N}$ 尺度与前文无约束 RCM

相同；平衡构型数少一个约 $\sqrt{N}$ 因子，故须核对定理实际适用的无约束/平衡版本。定理亦未明写低代价连续极限所需相区；在 $\kappa < 1$ 时已有指数多个零代价，不可能同时具有所述严格正的指数极限。不将这一草稿版本认证为条件齐全的严格定理。

这些定理及临界点附近更精细标度结果的证明，都分析给定代价划分数的积分表示。下面导出该表示，再通过证明相变存在概述一般策略，参见定理 7.2；其他证明请参阅原始文献。

7.5.1 积分表示

为简单起见，仍取 $\sum_i a_i$ 为偶数。奇数总和时可得类似结果，但最低代价为 1。

命题 7.5. *给定 $S = \{a_1, \dots, a_N\}$，且 $\sum_i a_i$ 为偶数，代价 $E = 0$ 的划分数 Z 可写为*

$$Z = 2^{N-1} \int_{-\pi}^{\pi} \frac{dx}{2\pi} \prod_{j=1}^{N} \cos(a_j x). \tag{7.15}$$

证明. 用自旋表示划分：$i \in \mathcal{A}$ 时 $\sigma_i = 1$，$i \in \mathcal{B} = [N] \setminus \mathcal{A}$ 时 $\sigma_i = -1$。于是 $Z = \frac{1}{2} \sum_{\sigma_1,\dots,\sigma_N} \mathbf{1}(\sum_j \sigma_j a_j = 0)$。因子 $1/2$ 来自两组交换对称性：序列 $\sigma_1, \dots, \sigma_N$ 与其整体反号表示同一划分。对任意整数 a，使用积分表示

$$\mathbf{1}(a = 0) = \int_{-\pi}^{\pi} \frac{dx}{2\pi} e^{ixa}, \tag{7.16}$$

得到

$$Z = \frac{1}{2} \sum_{\sigma_1,\dots,\sigma_N} \int_{-\pi}^{\pi} \frac{dx}{2\pi} e^{ix \sum_j \sigma_j a_j}. \tag{7.17}$$

对全部 σ_i 求和，即得式 (7.15)。 □

习题 7.6. *证明代价 $E \geq 1$ 的划分数也有类似表示，只需在被积函数中增加因子 $2\cos(Ex)$。对平衡划分，寻找类似的二维积分表示。*

式 (7.15) 的被积函数通常随 N 呈指数量级，并剧烈振荡，因此自然想到最陡下降法。它在 $\kappa \leq 1$ 相给出正确结果，但不易严格控制。下面采用简单的一、二阶矩估计，已足以导出相图的主要性质。更细致控制给出更准确预测，超出本章叙述范围。

7.5.2 矩估计

先计算完美划分数 Z 的前两个矩。

命题 7.6. *热力学极限下，Z 的一阶矩为*

$$\mathbb{E}Z = 2^{N(1-\kappa)} \sqrt{\frac{3}{2\pi N}} \, [1 + \Theta(1/N)]. \tag{7.18}$$

证明. 期望取遍 $\sum_i a_i$ 为偶数的数列。引入不施加奇偶约束的期望 $\mathbb{E}_i$，此时全部 a_i 独立同分布。显然 $\mathbb{E}_i Z = \frac{1}{2}\mathbb{E}Z$，因为只有总和偶数时才可能有零代价完美划分，而这一事件概率为 $1/2$。

由于 $\mathbb{E}_i$ 下的独立性，由式 (7.15) 得

$$\mathbb{E}Z = 2\mathbb{E}_i Z = 2^N \int_{-\pi}^{\pi} \frac{dx}{2\pi} [\mathbb{E}_i \cos(a_1 x)]^N. \tag{7.19}$$

余弦的期望为

$$\mathbb{E}_i \cos(a_1 x) = 2^{-M} \cos\left[\frac{x}{2}(2^M+1)\right] \frac{\sin(2^M x/2)}{\sin(x/2)} \equiv g(x). \tag{7.20}$$

稍作思考可知,热力学极限下积分 (7.19) 由非常接近 0 的 x 主导。具体地,缩放 $x = \widehat{x}/(2^M\sqrt{N})$,则 $g(x) = 1 - \widehat{x}^2/(6N) + \Theta(1/N^2)$。于是大 N 时,积分 (7.20) 的主导行为为

$$\mathbb{E}Z = 2^{N-M} \frac{1}{\sqrt{N}} \int_{-\infty}^{\infty} \frac{d\widehat{x}}{2\pi} \exp\left(-\frac{\widehat{x}^2}{6}\right) = 2^{N-M}\sqrt{\frac{3}{2\pi N}}, \tag{7.21}$$

忽略 $1/N$ 阶修正。 □

译注: 原文 "积分 (7.20)" 指向余弦均值,实际积分在式 (7.19)。g 的展开依赖固定缩放变量及 M 随 N 增长的区域,不能将 Θ 当作任意 $\widehat{x}$ 上的一致估计。这里 Z 为无约束划分计数,未施加 $\sum_i \sigma_i = 0$ 的平衡条件。

习题 7.7. 证明对于偶数 $E \le C2^M$、C 固定,代价为 E 的划分数在热力学极限也由式 (7.18) 给出。

译注: 原命题式 (7.18) 是期望,并非每个实例的精确计数;此外 $E > 0$ 的两个符号能量 $\pm E$ 对应同一个绝对代价,积分中的额外 $2\cos(Ex)$ 在很小正代价下通常给出零代价计数的两倍。若 E 与 2^M 相比不再可忽略,还要核对 Gaussian 偏移修正;原习题不静默更正。

命题 7.7. 当 $\kappa < 1$ 时,热力学极限下 Z 的二阶矩为

$$\mathbb{E}Z^2 = [\mathbb{E}Z]^2[1 + \Theta(1/N)]. \tag{7.22}$$

证明. 仍去掉总和为偶数的约束,得到

$$\mathbb{E}Z^2 = 2^{2N-1} \int_{-\pi}^{\pi} \frac{dx_1}{2\pi} \int_{-\pi}^{\pi} \frac{dx_2}{2\pi} [\mathbb{E}\cos(a_1 x_1)\cos(a_1 x_2)]^N. \tag{7.23}$$

两个余弦乘积的期望为

$$\mathbb{E}\cos(a_1 x_1)\cos(a_1 x_2) = \frac{1}{2}[g(x_+) + g(x_-)], \tag{7.24}$$

其中 $x_\pm = x_1 \pm x_2$。判断哪些积分区域在热力学极限重要时,须注意 $g(x)$ 为 2π 周期函数。二重积分在正方形 $[-\pi,\pi]^2$ 上进行。g 可非常接近 1 的区域,是 $x_1, x_2 = \Theta(1/(2^M\sqrt{N}))$ 的 "中心",以及四角 $(\pm\pi,\pm\pi)$ 附近;后者可由中心在 x_+ 或 x_- 上平移 $\pm 2\pi$ 得到。由周期性,四角总贡献等于中心贡献。因此先在中心附近换元 $x_{1(2)} = \widehat{x}_{1(2)}/(2^M\sqrt{N})$,正确的 $\mathbb{E}Z^2$ 等于这一积分的两倍。剩余计算直接给出 $\mathbb{E}Z^2 \simeq 2^{2N(1-\kappa)}3/(2\pi N)$。

为使论证成立,须证明中心之外的贡献在热力学极限可忽略。主导修正来自以下区域:

$$x_+ = \Theta(1/(2^M\sqrt{N})), \qquad x_- \text{ 任意}.$$

可用鞍点近似显式计算,结果量级为 $\Theta(2^{N(1-\kappa)}/N)$。因此 $\kappa < 1$ 时,中心或四角以外的相对贡献随 N 指数级地小。文献中给出了该二维积分的细致分析。 □

译注：原二阶矩证明在去除奇偶约束后又使用 $\mathbb{E}$，与前文 $\mathbb{E}_i$ 的区分不一致；乘积均值中的独立抽样应按未加约束的期望理解。近中心/四角估计为作者的证明概要，本轮未补写其未给出的全域一致余项控制。

两命题具有重要含义。$\kappa>1$ 时，$\mathbb{E}Z$ 随 N 指数级地小，Z 是非负整数，因此一阶矩方法说明大部分实例的 Z 确为 0。$\kappa<1$ 时，$\mathbb{E}Z$ 指数级地大，归一化变量 $Z/\mathbb{E}Z$ 的二阶矩小，故涨落小。二阶矩方法表明 Z 以高概率为正。于是证明了 $\kappa_c=1$ 处存在相变，即定理 7.2。[7]

习题 7.8. 通常地定义逆温度 β 下配分函数 $Z(\beta)=\sum_{\mathcal{A}} e^{-\beta E_{\mathcal{A}}}$。使用积分表示

$$e^{-|U|}=\int_{-\infty}^{\infty}\frac{dx}{\pi}\frac{1}{1+x^2}e^{-ixU}, \tag{7.25}$$

以及 $\sum_{k\in\mathbb{Z}} 1/(1+x^2k^2)=\pi/[x\tanh(\pi/x)]$，证明独立同分布 a_i 的“退火平均”为

$$\mathbb{E}_i Z=2^{N(1-\kappa)}\sqrt{\frac{3}{2\pi N}}\frac{1}{\tanh(\beta/2)}[1+\Theta(1/N)]. \tag{7.26}$$

译注：配分函数是否将互补划分计数一次，与无奇偶约束的 $\mathbb{E}_i$ 因子必须相容。若按前文互补等价类计数，则 $\beta\to\infty$ 时应趋于 $\mathbb{E}_i Z(\infty)=\frac{1}{2}\mathbb{E}Z$；原式极限却为式 (7.18) 的首项，存在两倍计数差异。原式保留，未认定其归一化已一致。

注释

Hayes 的论文（Hayes, 2002） 是数字划分的良好初等介绍。NP 完全性是经典结果，可见 Papadimitriou（1994）、Garey 和 Johnson（1979） 等教科书。Karmarkar–Karp 算法在技术报告（Karmarkar and Karp, 1982） 中提出；Korf 的完备算法见 Korf（1998）。

关于独立同分布随机数划分已有大量工作。特别地，在大 κ 极限将代价乘 2^{-M} 缩放后，便涉及 a_i 在 $[0,1]$ 上独立同分布的实数情形。早在 1986 年，Karmarkar、Karp、Lueker 和 Odlyzko 就研究了该情形最优代价的标度（Karmarkar, Karp, Lueker and Odlyzko, 1986）。算法上这是很有挑战的问题：最优划分代价为 $O(\sqrt{N}\,2^{-N})$，而所有已知启发式表现不佳。例如 KK 找到的解代价为 $O(\exp[-0.72(\log N)^2])$，远离最优标度（Yakir, 1996）。[8]

Gent 和 Walsh 数值识别了相变（Gent and Walsh, 1998）；Ferreira 和 Fontanari（1998） 及 Mertens（1998） 用统计物理方法研究它。Mertens 还提出随机代价模型（Mertens, 2000）。其综述（Mertens, 2001） 很好地总结这些工作，并有助于解答习题 7.2、7.4、7.7。习题 7.3 的奇偶问题见 Bauke（2002）。

在这些统计力学研究基础上，Borgs、Chayes 和 Pittel 对无约束问题建立了十分细致的严格结果（Borgs, Chayes and Pittel, 2001）；稍后又与 Mertens 合作处理约束情形（Borgs, Chayes, Mertens and Pittel, 2003）。这些结果远超本章所列定理，鼓励感兴趣读者研读原文，其中还有严格控制第 7.5 节积分表示所需的技术细节，以及习题 7.5、7.6 的解答。

译注：作者—年份引文保留原文标识，可唯一匹配者已与 Part F 连接。

[7] 译注：归一化变量的二阶矩趋于 1，趋零的是其方差。以上积分计数的是无约束划分；要证明前述含“平衡”限定的版本，还须加入平衡约束，不能仅由这一无约束计数直接推出。

[8] 译注：源稿这两个 O 表达式的括号不完整，此处仅补配定界符，不改指数与系数。“所有已知”按草稿年代理解，不据此声称截至当前没有更好方法。

第八章　复本理论导论

过去 25 年间，复本方法已发展成一种相当精巧的工具，用于自旋玻璃、蛋白质折叠、超导体中的涡旋、组合优化等各类理论问题。本书采用另一种等价、且在我们看来更具体的方法，即所谓的 “腔方法”。实际上，跳过本章不会严重妨碍读者理解本书其余部分。

不过，了解复本仍有启发。复本方法是一种奇妙而强大的构造。它还不是严格的方法，包含一些形式操作，以及几条看起来可能任意的规定。然而这些规定是完全明确的，因而可以将它视为一种 “基本自动化” 的解析工具。它的若干最重要预言也已通过其他方法得到严格确认。其中一个有趣方面是复本间 “重叠” 的作用：研究对象中微妙的概率结构，往往最容易用这些变量表达。

这里借助第 五章随机能量模型（REM）的简单性介绍复本，这是第 8.1 节的内容。第 8.2 节引入并讨论更复杂的自旋模型；第 8.3 节讨论最简单的复本对称性破缺方案与极值统计的关系；最后的附录简述复本空间中的局部稳定性分析，这是复本方法最常用的自洽性检查之一。[1]

8.1　随机能量模型的复本解

如第 5.1 节所述，REM 的一个样本（或实例）由 2^N 个能级 E_j 给定，$j \in \{1, \dots, 2^N\}$。这些能级是均值 0、方差 $N/2$ 的独立同分布高斯随机变量。一个构型就是某能级的指标 j。给定能级 $\{E_1, \dots, E_{2^N}\}$ 的样本，其配分函数为

$$Z = \sum_{j=1}^{2^N} \exp(-\beta E_j), \tag{8.1}$$

本身也是随机变量，用物理学语言说，“Z 随样本涨落”。第 五章论证了强度热力学势的自平均性，即大 N 极限下其分布尖锐地集中在均值附近。其中自由能密度 $f = -(\beta N)^{-1} \log Z$ 尤为重要，因为其他势可从自由能的导数求得。配分函数则不同，即使系统很大，分布仍然很宽；特别是在低温相中，其平均值受极罕见样本主导。为了适当地描述系统，需要计算对数配分函数的平均 $\mathbb{E} \log Z$；它除以相应常数便给出平均自由能密度。

计算配分函数的整数阶矩 $\mathbb{E} Z^n$（$n \in \mathbb{N}$）比直接求 $\mathbb{E} \log Z$ 容易得多，因为 Z 是许多 “简单” 项之和。另一方面，若能对任意实数 n，或至少对足够小的 n，求出 $\mathbb{E} Z^n$，就能利用例如

$$\mathbb{E} \log Z = \lim_{n \to 0} \frac{1}{n} \log(\mathbb{E} Z^n) \tag{8.2}$$

[1] 译注：本章关于方法的严格性、历史进展和文献状态均为所选作者草稿写作时的陈述，不作为当前数学进展的综述。

确定平均对数配分函数。思路是先 “仿佛” n 为整数那样计算 $\mathbb{E}Z^n$，到得出足够易处理的表达式时，再 “记起” n 实际上须为实数，并作相应处理。这多少像解析延拓，但实际上还要加上几味调料……

第一步注意到 Z^n 可写成 n 重求和：

$$Z^n = \sum_{i_1,\dots,i_n=1}^{2^N} \exp(-\beta E_{i_1} - \cdots - \beta E_{i_n}). \tag{8.3}$$

它是一个新系统的配分函数。新系统的构型由 n 元组 $(i_1,\dots,i_n)$ 给定，其中 $i_a \in \{1,\dots,2^N\}$，能量为 $E_{i_1\dots i_n} = E_{i_1} + \cdots + E_{i_n}$。换言之，新系统由原系统的 n 个统计独立的副本组成；物理学上说，它们没有相互作用。我们称这些副本为复本。

为对式 (8.3) 取平均，先改写为

$$Z^n = \sum_{i_1,\dots,i_n=1}^{2^N} \prod_{j=1}^{2^N} \exp\left[-\beta E_j \left(\sum_{a=1}^{n} \mathbb{I}(i_a = j)\right)\right]. \tag{8.4}$$

利用期望的线性、E_j 的独立性和高斯分布，容易得到

$$\mathbb{E}Z^n = \sum_{i_1,\dots,i_n=1}^{2^N} \exp\left(\frac{\beta^2 N}{4} \sum_{a,b=1}^{n} \mathbb{I}(i_a = i_b)\right). \tag{8.5}$$

$\mathbb{E}Z^n$ 也可解释为一个新 “复本化” 系统的配分函数。构型仍由 $(i_1,\dots,i_n)$ 给定，但能量变为 $E_{i_1\dots i_n} = -(N\beta/4)\sum_{a,b=1}^{n} \mathbb{I}(i_a = i_b)$。

这个系统有几项有趣性质。首先，它已不是无序系统：能量是构型的确定函数。其次，复本间有相互作用，能量无法写成各复本单独贡献之和。这种相互作用使不同复本相互吸引，最低能构型特别地由 $i_1 = \cdots = i_n$ 得到，能量为 $-N\beta n^2/4$。第三，能量本身依赖温度，方式很简单，低温时效应更强。

相互作用的来源容易理解。对原问题的某个固定样本，低温（$\beta \gg 1$）时 Boltzmann 分布集中在最低能级，各复本很可能处于同一构型。对样本分布取平均后，我们不再知道哪个 $i \in \{1,\dots,2^N\}$ 最低能，却仍能看出复本偏好相同状态。这并不神秘：给定样本，也就是给定各能级 E_j 的实现时，$(i_1,\dots,i_n)$ 的各分量条件独立；不以该实现为条件时，它们便变得相关。

给定复本构型，引入 $n \times n$ 的重叠矩阵 $Q_{ab} = \mathbb{I}(i_a = i_b) \in \{0,1\}$。式 (8.5) 的求和项仅通过这一矩阵依赖构型，故可写成

$$\mathbb{E}Z^n = \sum_{Q} \mathcal{N}_N(Q) \exp\left(\frac{N\beta^2}{4} \sum_{a,b=1}^{n} Q_{ab}\right). \tag{8.6}$$

$\mathcal{N}_N(Q)$ 是重叠矩阵为 $Q = \{Q_{ab}\}$ 的构型数，求和遍历对角元为 1 的对称 $\{0,1\}$ 矩阵。这种矩阵共有 $2^{n(n-1)/2}$ 个，而复本化系统有 2^{Nn} 个构型，因而自然猜想 $\mathcal{N}_N(Q) \doteq \exp[Ns(Q)]$ 的大偏差形式。

习题 8.1. 证明重叠矩阵总有如下形式：存在将 n 个复本划分成 n_g 组的划分 $G_1,\dots,G_{n_g}$，即 $G_1 \cup \cdots \cup G_{n_g} = \{1,\dots,n\}$，不同组满足 $G_i \cap G_j = \varnothing$，使得 a,b 同组时 $Q_{ab} = 1$，否则为 0。证明上述大偏差形式成立，且 $s(Q) = n_g \log 2$。

译注：不是每个对称 0–1 矩阵都对应实际构型；不满足同组关系传递性的矩阵计数为 0，可赋 $s(Q)=-\infty$。固定整数 n_g、$2^N \geq n_g$ 时，计数恰为 $\prod_{k=0}^{n_g-1}(2^N-k)$；指数等价针对固定复本数取 $N\to\infty$。

据此，复本化配分函数为

$$\mathbb{E}Z^n \doteq \sum_{Q} e^{Ng(Q)}, \qquad g(Q) \equiv \frac{\beta^2}{4}\sum_{a,b=1}^{n} Q_{ab} + s(Q). \tag{8.7}$$

复本方法用鞍点法估计该和。[2]随后再讨论向非整数 n 的“外推”。除这最后一步外，整个过程与第 2.5.2 节处理 Curie–Weiss 模型完全类似，相关背景也见第 4.3.3 节。

8.1.1 复本对称鞍点

$g(Q)$ 对复本置换不变：设 $\pi\in S_n$ 为 n 个对象的置换，$Q^{\pi}_{ab}=Q_{\pi(a)\pi(b)}$，则 $g(Q^{\pi})=g(Q)$。这是所有复本从一开始便等价的直接结果。这一对称性称为**复本对称性**，是复本方法的一般特征。若主导鞍点也有此对称性，即任意 π 下 $Q^{\pi}=Q$，便称系统**复本对称**（RS）；否则，复本对称性在大 N 极限下自发破缺，含义与第 2.5.2 节讨论的一样。

最简单的想法是寻找复本对称鞍点。置换不变要求 $Q_{aa}=1$，且任意 $a\neq b$ 时 $Q_{ab}=q_0$，只剩两种可能：

- $Q_{\mathrm{RS},0}$ 由 $q_0=0$ 定义。此时 $\mathcal{N}_N(Q_{\mathrm{RS},0})=2^N(2^N-1)\cdots(2^N-n+1)$，故 $s(Q_{\mathrm{RS},0})=n\log 2$，$g(Q_{\mathrm{RS},0})=n(\beta^2/4+\log 2)$。

- $Q_{\mathrm{RS},1}$ 由 $q_0=1$ 定义，即 $i_1=\cdots=i_n$。共有 2^N 个符合约束的 n 元组，因此 $s(Q_{\mathrm{RS},1})=\log 2$，$g(Q_{\mathrm{RS},1})=n^2\beta^2/4+\log 2$。

暂时限制于这些 RS 鞍点，需判断哪一个主导求和。图 8.1 绘出 $n=3$ 和 $n=0.5$ 时 $g_0(n,\beta)\equiv g(Q_{\mathrm{RS},0})$、$g_1(n,\beta)\equiv g(Q_{\mathrm{RS},1})$ 随 $T=1/\beta$ 的变化。所得表达式是 n 的多项式，因此也能画出非整数 n 的曲线。

[2]原注：这里谈“鞍点”并不十分准确，因为是离散求和；意思是用单个“主导”项估计式 (8.7)。

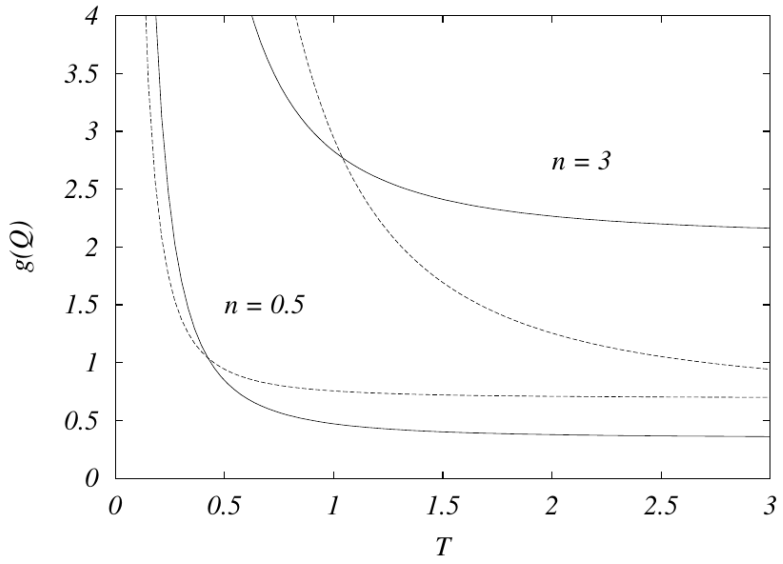


图 8.1: REM 的率函数 $g(Q)$ 随温度的变化，参见式 (8.7)。在 $n=3$、$n=0.5$ 时，分别对两个复本对称鞍点 $Q_{\mathrm{RS},0}$（实线）、$Q_{\mathrm{RS},1}$（虚线）求值。取自 Part B PDF 第 55 页（原 147）。

$n>1$ 时，总与 $n=3$ 的情形定性相同。令 $\beta_c(n)=\sqrt{4\log 2/n}$，则 $\beta>\beta_c(n)$ 时 $g_1>g_0$，$\beta<\beta_c(n)$ 时 $g_1<g_0$。暂且假设式 (8.7) 由复本对称项主导，便有

$$\mathbb{E}Z^n \doteq \exp\{N\max[g_0(\beta,n),g_1(\beta,n)]\}.$$

因此 $\beta_c(n)$ 可解释为 n 复本系统的相变点。高温时 $q_0=0$ 主导，复本基本独立；低温时 $q_0=1$ 主导，复本锁在一起。这与前节的定性讨论一致。

$n<1$ 时出现问题。相变仍在 $\beta_c(n)=\sqrt{4\log 2/n}$，但高、低温区间交换角色：低温时 $g_1<g_0$，高温时 $g_1>g_0$。若仍选使 $g(Q)$ 最大的鞍点，物理上会得出低温独立、高温相关的荒谬结果，数学上也不合理，因为 $g_1(\beta,n)$ 在小 n 时不呈线性，$n\to 0$ 时 $\mathbb{E}Z^n$ 不趋于 1。⋆事实上，复本方法规定：$n<1$ 时须用 $g(Q)$ 的最小值估计式 (8.7)！这里没有这一规定的数学论证。下面的例子及后续章节将概述物理学家为此给出的一些理由。

例 8.1. 为理解上述说法，考虑玩具问题：对一般实数 n 的 $Z_{\mathrm{toy}}(n)=(2\pi/N)^{n(n-1)/4}$ 应用复本规定。整数 n 时有积分表示

$$Z_{\mathrm{toy}}(n)=\int e^{-\frac{N}{2}\sum_{(ab)}Q_{ab}^2}\prod_{(ab)}dQ_{ab}\equiv\int e^{Ng(Q)}\prod_{(ab)}dQ_{ab}. \tag{8.8}$$

(ab) 遍历 $a,b\in\{1,\dots,n\}$、$a\neq b$ 的所有无序对，Q_{ab} 在实线上积分。先假设积分由复本对称点 $Q_{ab}^*=q_0$ 主导，得到 $g(Q^*)=-n(n-1)q_0^2/2$。随后确定 $q_0\in\mathbb{R}$。显然取 $q_0=0$ 可恢复正确结果 $Z_{\mathrm{toy}}(n)\doteq 1$，且这是使 $g(Q^*)$ 驻定的唯一选择。然而 $n<1$ 时，$q_0=0$ 是 $g(Q^*)$ 的极小值而非极大值。形式上的解释是，自由度数目，即 $a\neq b$ 的矩阵元数，在 $n<1$ 时成为负数。

译注： 原文紧接式 (8.8) 的系数照录；按所声明的无序对求和，实际 $g(Q^*)=-n(n-1)q_0^2/4$，相差因子 2，不影响此例关于驻点类型的定性说明。“唯一” 排除 $n=0,1$ 的退化情形；$\doteq 1$ 仅指 N 的主导指数。

这是复本方法最奇特却无法回避的一点。另一个随后讨论的难题，是 $N\to\infty$ 与 $n\to 0$ 两个极限能否交换。先选 $q_0=0$，利用式 (8.2)，并假设可以交换极限，得到 RS 自由能

$$\begin{aligned}-\beta f &\equiv \lim_{N\to\infty}\frac{1}{N}\mathbb{E}\log Z=\lim_{N\to\infty}\lim_{n\to 0}\frac{1}{Nn}\log(\mathbb{E}Z^n)\\ &=\lim_{n\to 0}\frac{1}{n}g_0(n,\beta)=\frac{\beta^2}{4}+\log 2.\end{aligned}\tag{8.9}$$

与正确结果式 (5.15) 比较可见，这只在高温相 $\beta<\beta_c=2\sqrt{\log 2}$ 正确，漏掉了相变；RS 框架无法在 $\beta>\beta_c$ 得到正确解。

8.1.2 一步复本对称性破缺鞍点

$\beta>\beta_c$ 时，式 (8.7) 由非复本对称矩阵主导。问题是找出这些新鞍点，并使其在 $n\to 0$ 时仍有意义。可尝试放宽对称性要求，扩大优化的矩阵子空间。Parisi 最早在更复杂的自旋玻璃平均场理论中提出*复本对称性破缺* (RSB) 方案，以递归步骤逐渐扩大搜索鞍点的 Q 矩阵空间。

第一步称为*一步复本对称性破缺* (1RSB)。先设 n 为 m 的倍数，将复本分成 n/m 组，每组 m 个，并取

$$\begin{aligned}&Q_{aa}=1,\\ &Q_{ab}=q_1\quad \text{若 } a,b \text{ 属于同一组},\\ &Q_{ab}=q_0\quad \text{若 } a,b \text{ 属于不同组}.\end{aligned}\tag{8.10}$$

REM 的矩阵元只能为 0 或 1，所以仅当 $q_1=1$、$q_0=0$ 时，该拟设才不同于 RS。适当重排指标后，这意味着 $i_1=\cdots=i_m$、$i_{m+1}=\cdots=i_{2m}$，依此类推。符合约束的元组数为 $2^N(2^N-1)\cdots(2^N-n/m+1)$，故 $s(Q)=(n/m)\log 2$，率函数为 $g(Q_{\mathrm{RSB}})=g_{\mathrm{RSB}}(\beta,n,m)$：

$$g_{\mathrm{RSB}}(\beta,n,m)=\frac{\beta^2}{4}nm+\frac{n}{m}\log 2.\tag{8.11}$$

按前节讨论，先对 m 极小化，再取 $n\to 0$。式 (8.11) 可看成关于 n 及 $m\neq 0$ 的解析函数。此后便不再要求 n,m 为整数、n 为 m 的倍数。对 m 求导，在 $m=m_s(\beta)$ 时为 0，其中

$$m_s(\beta)\equiv\frac{2\sqrt{\log 2}}{\beta}=\frac{\beta_c}{\beta}.\tag{8.12}$$

代回并再次假设极限可交换，得到

$$-\beta f=\lim_{n\to 0}\frac{1}{n}\min_m g_{\mathrm{RSB}}(\beta,n,m)=\beta\sqrt{\log 2},\tag{8.13}$$

正是 $\beta>\beta_c$ 的正确结果 $f=-\sqrt{\log 2}$。事实上，若接受整数 n,m 时的 $1\le m\le n$ 在 $n\to 0$ 时转为 $n=0\le m\le 1$，便能恢复所有温度的正确自由能；后面还将说明这一规定的其他依据。将极小化约束在 $[0,1]$ 后，低温鞍点为 $m=\beta_c/\beta$，高温时 m 停在 1。图 8.2 给出若干 β 下的 g_{RSB}/n。

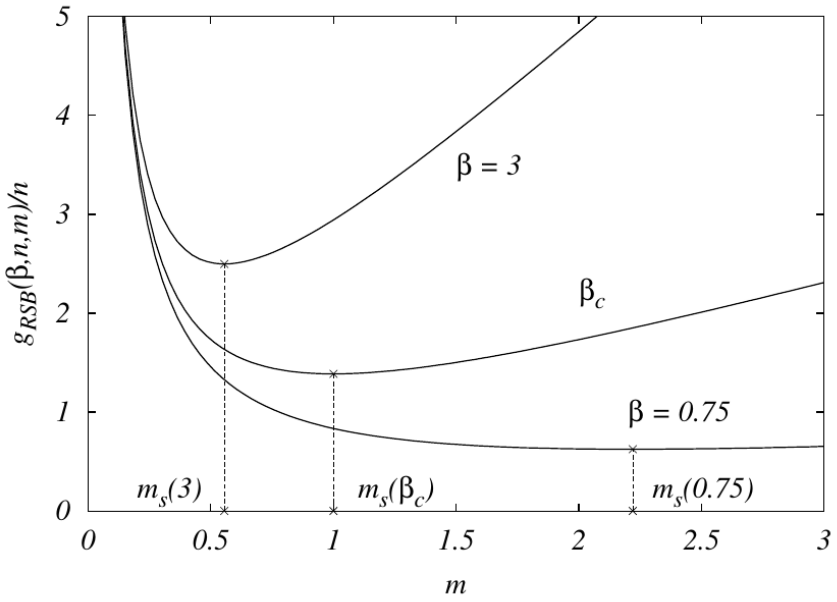


图 8.2: 在一步复本对称性破缺鞍点计算的率函数 $g(Q)$，参见式 (8.7)，随破缺参数 m 的变化。取自 Part B PDF 第 57 页（原 149）。

8.1.3 关于复本解的讨论

人们或许会以为，复本方法只是用整数阶矩重建概率分布的一种花哨方式：已知 $\mathbb{E}Z^n$，希望推断 Z 的整个分布，特别是 $\mathbb{E}\log Z$。这是概率论中的标准问题。若整数阶矩在 $n\to\infty$ 时增长不太快，就能重建分布。典型结果如下。

定理 8.2 (Carleman)**.** *设实随机变量 X 的矩 $\mu_n=\mathbb{E}X^n$ 满足*

$$\sum_{n=1}^{\infty}\mu_{2n}^{-1/(2n)}=\infty. \tag{8.14}$$

则任何具有相同各阶矩的变量都与 X 同分布。

例如，若矩至多指数增长，$\mathbb{E}X^n\sim e^{\alpha n}$，其值便完全确定 X 的分布。将结果应用于 REM：第 8.1.1 节的 RS 计算容易转成下界

$$\mathbb{E}Z^n\geq e^{ng(Q_{\mathrm{RS},0})}\geq e^{N\beta^2n^2/4}. \tag{8.15}$$

因此式 (8.14) 的和收敛，整数阶矩未必唯一决定 Z 的分布。**译注：** 式 (8.15) 按可见原稿保留。第一指数写 n 而非 N，并使用 $Q_{\mathrm{RS},0}$，一般不能支持右侧 n^2 下界；由所有复本取同一能级的项可直接得到严格下界 $\mathbb{E}Z^n\geq 2^N e^{N\beta^2n^2/4}$（正整数 n）。Carleman 条件是充分条件，失效本身不证明矩不唯一。

习题 8.2. *设 $Z=e^{-F}$，F 为高斯随机变量，密度为*

$$p(F)=\frac{1}{\sqrt{2\pi}}e^{-F^2/2}. \tag{8.16}$$

计算 Z 的整数阶矩，它们是否满足 *Carleman* 定理的假设？证明若用 $p_a(F) = p(F)[1 + a\sin(2\pi F)]$、$|a| < 1$ 替换密度，各阶矩不变（引自 *Feller*, *1968*）。

复本方法中，向非整数 n 有多种可能的解析延拓，关键是选对。Parisi 拟设及后面将讨论的高阶 RSB 推广，给出了明确的一类延拓，并在许多问题中成为正确选择。

谨慎的读者会注意到：若能级分布支集有界，矩就不会增长得如此迅速。例如将高斯 E_i 条件化于 $[-E_{\max}, E_{\max}]$，便有 $Z \le Z_{\max} = 2^N e^{\beta E_{\max}}$，从而 $\mathbb{E}Z^n \le Z_{\max}^n$，整个分布可由整数阶矩恢复。然而这要求在固定系统大小 N 时精确知道全部 $1 \le n < \infty$ 的矩。一般能算到的只是固定 n 下的大 N 行为；多数时候，这些信息不足以保证向 $n \to 0$ 延拓的唯一性。

实际上，复本方法可看成在极限存在时计算

$$\psi(n) = \lim_{N\to\infty} \frac{1}{N} \log \mathbb{E}Z^n \tag{8.17}$$

的步骤。常见情况下，$f = -(\beta N)^{-1}\log Z$ 满足 $P_N(f) \doteq \exp[-NI(f)]$ 的大偏差原理，此时

$$\mathbb{E}Z^n \doteq \int df\, e^{-NI(f) - N\beta n f} \doteq \exp\{-N \inf_f [I(f) + \beta n f]\}. \tag{8.18}$$

故 $\psi(n) = -\inf_f[I(f) + \beta n f]$。反过来，可用 Gärtner–Ellis 定理 4.12 从 ψ 推断 f_N 的大偏差性质。典型自由能密度是 $I(f)$ 的全局最小值位置；通常需要趋于 0 的 n 才能算出它，不能仅由整数 n 的值推断。

8.1.4 凝聚

第 五章已讨论低温 “玻璃” 相与概率测度向少数构型凝聚的联系，并用参与比 Y 定量描述。命题 5.3 给出，REM 在任意 $\beta > \beta_c$ 时 $\lim_{N\to\infty}\mathbb{E}Y = 1 - \beta_c/\beta$。复本计算只需几行便可恢复此结果。

参与比为 $Y = \sum_{j=1}^{2^N} p_j^2$，其中 $p_j = e^{-\beta E_j}/Z$ 是第 j 能级的 Boltzmann 概率。因此

$$\begin{aligned}
\mathbb{E}Y &= \lim_{n\to 0} \mathbb{E}\left[Z^{n-2} \sum_{i=1}^{2^N} e^{-2\beta E_i} \right] && [Y \text{ 的定义}] \\
&= \lim_{n\to 0} \mathbb{E}\left[\sum_{i_1,\dots,i_{n-2}} e^{-\beta(E_{i_1}+\cdots+E_{i_{n-2}})} \sum_{i=1}^{2^N} e^{-2\beta E_i} \right] && [\text{设 } n \in \mathbb{N}] \\
&= \lim_{n\to 0} \mathbb{E}\left[\sum_{i_1,\dots,i_n} e^{-\beta(E_{i_1}+\cdots+E_{i_n})} \mathbb{I}(i_{n-1} = i_n) \right] \\
&= \lim_{n\to 0} \frac{1}{n(n-1)} \sum_{a\neq b} \mathbb{E}\left[\sum_{i_1,\dots,i_n} e^{-\beta(E_{i_1}+\cdots+E_{i_n})} \mathbb{I}(i_a = i_b) \right] && [\text{对称化}] \\
&= \lim_{n\to 0} \frac{1}{n(n-1)} \sum_{a\neq b} \frac{\mathbb{E}[\sum_{i_1,\dots,i_n} e^{-\beta(E_{i_1}+\cdots+E_{i_n})}\mathbb{I}(i_a = i_b)]}{\mathbb{E}[\sum_{i_1,\dots,i_n} e^{-\beta(E_{i_1}+\cdots+E_{i_n})}]} && [\text{分母} \to 1] \\
&= \lim_{n\to 0} \frac{1}{n(n-1)} \sum_{a\neq b} \langle Q_{ab} \rangle_n . && (8.19)
\end{aligned}$$

复本指标 a,b 遍历 $\{1,\dots,n\}$，构型指标 i_a 遍历 $\{1,\dots,2^N\}$。最后一步引入

$$\langle f(Q)\rangle_n \equiv \frac{\sum_Q f(Q)\mathcal{N}_N(Q)e^{\frac{N\beta^2}{4}\sum_{a,b}Q_{ab}}}{\sum_Q \mathcal{N}_N(Q)e^{\frac{N\beta^2}{4}\sum_{a,b}Q_{ab}}}, \tag{8.20}$$

并将构型求和拆成对重叠矩阵的求和及对同一重叠矩阵下各元组的求和。$\langle\cdot\rangle_n$ 可解释为复本化系统中的期望。

大 N 时 $\mathcal{N}_N(Q)\doteq e^{Ns(Q)}$，期望由主导鞍点项给出：$\langle f(Q)\rangle_n \simeq f(Q^*)$。[3]如前所述，低温相中鞍点矩阵为式 (8.10)，于是

$$\begin{aligned}
\mathbb{E}Y &= \lim_{n\to0}\frac{1}{n(n-1)}\sum_{a\neq b}Q_{ab}^{\mathrm{1RSB}} && \text{[鞍点]}\\
&= \lim_{n\to0}\frac{n[(n-m)q_0+(m-1)q_1]}{n(n-1)} && \text{[式 (8.10)]}\\
&= 1-m = 1-\frac{\beta_c}{\beta} && [q_0=0,\ q_1=1].
\end{aligned} \tag{8.21}$$

这与命题 5.3 的直接组合计算一致。也证实 1RSB 拟设只有 $0\le m\le 1$ 才有意义，因为 Y 按定义为正。与第 5.3 节相比，复本推导十分简洁。

乍看起来，式 (8.19) 比自由能计算多加了假设：引入复本，把参与比中的 Z^{-2} 写成正幂 Z^{n-2} 的解析延拓。实际上，这与式 (8.2) 等价；基本原因是期望值可由 $\log Z$ 对某些参数求导得到。[4]

习题 8.3. 用复本方法证明 $T<T_c$ 时

$$\mathbb{E}\left(\sum_{j=1}^{2^N}p_j^r\right) = \frac{\Gamma(r-m)}{\Gamma(r)\Gamma(1-m)} = \frac{(r-1-m)(r-2-m)\cdots(1-m)}{(r-1)(r-2)\cdots1}, \tag{8.22}$$

其中 $\Gamma(x)$ 为 *Euler Gamma* 函数。

译注： 右侧有限乘积对应整数 $r\ge2$；Gamma 表达式的推广需 $r>m$ 等矩收敛条件。

习题 8.4. 用复本方法证明 $T<T_c$ 时

$$\mathbb{E}(Y^2) = \frac{3-5m+2m^2}{3}. \tag{8.23}$$

8.2 全连接p 自旋玻璃模型

复本方法以简洁有效但非严格的方式计算 REM 自由能密度；低温时采用复本对称性破缺，结果即为精确答案。不过，对不能直接用组合方法求解的更复杂问题，其能力更显著。本节应用于所谓的 “p 自旋玻璃” 模型。该模型源于自旋玻璃理论，其特征是相互作用涉及 $p\ge2$ 个自

[3]原注：若主导项对应非复本对称矩阵 Q^*，置换复本指标得到的所有项权重相同。因此最好计算对称函数 $f(Q)=f(Q^\pi)$ 的平均，式 (8.19) 正是如此。

[4]译注：此处及下面的期望公式按作者的热力学极限复本计算理解，并非有限 N 的精确等式；极限交换和延拓仍属本章已声明的规定。

旋组成的组。它推广了通常相互作用只涉及两个自旋（$p=2$）的模型（参见第 2.6 节）。这增加了 p 这一自由度：$p=2$ 与 $p\geq 3$ 出现不同物理图景，大 p 时还有一些有趣的简化。

构型空间由 N 个 Ising 自旋的 2^N 个构型组成，$\sigma=\{\sigma_1,\dots,\sigma_N\}$ 的能量为

$$E(\sigma)=-\sum_{i_1<i_2<\cdots<i_p} J_{i_1\dots i_p}\sigma_{i_1}\cdots\sigma_{i_p}, \tag{8.24}$$

$\sigma_i\in\{\pm1\}$。这是无序系统，一个样本由全部 $1\leq i_1<\cdots<i_p\leq N$ 的耦合 $J_{i_1\dots i_p}$ 确定。它们独立同分布，为均值 0、方差 $\mathbb{E}J^2_{i_1\dots i_p}=p!/(2N^{p-1})$ 的高斯变量，概率密度为

$$P(J)=\sqrt{\frac{\pi p!}{N^{p-1}}}\exp\left(-\frac{N^{p-1}}{p!}J^2\right). \tag{8.25}$$

译注：原式前因子照录，积分不为 1；与所给方差相容的归一化因子应为 $\sqrt{N^{p-1}/(\pi p!)}$。

p 自旋模型是*无限程相互作用*模型，自旋位置没有欧氏距离的概念。又称*全连接*模型，因为每个自旋直接与其余所有自旋相互作用；这正是耦合方差特殊标度的原因。判断标度是否适当的简单标准是：翻转单个自旋引起的能量变化应为 1 的量级，即 $N\to\infty$ 时有限。更确切地，令 $\sigma^{(i)}$ 为翻转自旋 i 后的构型，并定义 $\Delta_i=[E(\sigma^{(i)})-E(\sigma)]/2$。容易看出 $\Delta_i=\sum_{i_2\dots i_p}J_{ii_1\dots i_p}\sigma_i\sigma_{i_1}\cdots\sigma_{i_p}$。求和含 $\Theta(N^{p-1})$ 项；若 σ 随机，每项中的自旋乘积以各 1/2 概率为 $+1$、-1。式 (8.25) 的标度保证 Δ_i 在大 N 时有限，而 $p!$ 因子只是约定。[5]

为什么要求 Δ_i 为 1 的量级？它估计单个自旋与系统其余部分的相互作用。若远大于 1，自旋就会完全冻结在令 Δ_i 为正的方向上，温度不再起作用；若远小于 1，自旋实际上便与其他自旋独立。

习题 8.5. *另一个论证如下。证明高温 $\beta\ll1$ 时，$Z=2^N[1+\frac12\beta^2\sum_{i_1<\cdots<i_p}J^2_{i_1\dots i_p}+O(\beta^3)]$。这意味着 $N^{-1}\mathbb{E}\log Z=\log2+C_N\beta^2/2+O(\beta^3)$，其中 $C_N=1$。若方差取不同标度会怎样？要使 C_N 有有限的 $N\to\infty$ 极限，需要什么标度？*

译注：按给定方差，$C_N=N^{-1}\binom{N}{p}p!/(2N^{p-1})=\frac12\prod_{k=0}^{p-1}(1-k/N)\to1/2$，不是原文的 1。此展开首先是固定 N 的高温展开，余项的 N 一致性另需控制。

$p=2$ 最接近原始自旋玻璃问题，称为 Sherrington–Kirkpatrick（SK）模型。

8.2.1 复本计算

先将 Z^n 写成 n 个无相互作用复本 σ_i^a（$i\in\{1,\dots,N\}$，$a\in\{1,\dots,n\}$）的配分函数：

$$Z^n=\sum_{\{\sigma_i^a\}}\prod_{i_1<\cdots<i_p}\exp\left(\beta J_{i_1\dots i_p}\sum_{a=1}^{n}\sigma^a_{i_1}\cdots\sigma^a_{i_p}\right). \tag{8.26}$$

利用耦合独立性及熟知的高斯恒等式

$$\mathbb{E}e^{\lambda X}=e^{\frac12\Delta\lambda^2}, \tag{8.27}$$

[5]译注：此处 Δ_i 求和的原下标 $i_2\dots i_p$ 与乘积及耦合所写 $i_1\dots i_p$ 不一致，照录并提示。由能量定义，应对包含 i 的全部 p 元组中的其余 $p-1$ 个指标求和。

其中 $\mathbb{E}X=0$、$\mathbb{E}X^2=\Delta$，容易对耦合取平均，得到

$$\begin{aligned}\mathbb{E}Z^n &= \sum_{\{\sigma_i^a\}} \exp\left(\frac{\beta^2}{4}\frac{p!}{N^{p-1}}\sum_{i_1<\cdots<i_p}\sum_{a,b}\sigma_{i_1}^a\sigma_{i_1}^b\cdots\sigma_{i_p}^a\sigma_{i_p}^b\right)\\ &\doteq \sum_{\{\sigma_i^a\}}\exp\left[\frac{\beta^2}{4N^{p-1}}\sum_{a,b}\left(\sum_i \sigma_i^a\sigma_i^b\right)^p\right].\end{aligned} \tag{8.28}$$

忽略了指标重合 $i_l=i_k$ 的修正，因为它不影响主导指数阶。对每个 $a<b$ 用恒等式引入 Q_{ab} 和 λ_{ab}：

$$\begin{aligned}1 &= \int dQ_{ab}\,\delta\left(Q_{ab}-\frac{1}{N}\sum_{i=1}^N\sigma_i^a\sigma_i^b\right)\\ &= N\int dQ_{ab}\int\frac{d\lambda_{ab}}{2\pi}\exp\left[-i\lambda_{ab}\left(NQ_{ab}-\sum_i\sigma_i^a\sigma_i^b\right)\right],\end{aligned} \tag{8.29}$$

积分均沿实线。代入式 (8.28) 得到

$$\begin{aligned}\mathbb{E}Z^n &\doteq \int\prod_{a<b}dQ_{ab}\sum_{\{\sigma_i^a\}}\exp\left(\frac{N\beta^2}{4}n+\frac{N\beta^2}{2}\sum_{a<b}Q_{ab}^p\right)\\ &\qquad\times\prod_{a<b}\delta\left(Q_{ab}-\frac{1}{N}\sum_{i=1}^N\sigma_i^a\sigma_i^b\right)\\ &\doteq \int\prod_{a<b}(dQ_{ab}\,d\lambda_{ab})\,e^{-NG(Q,\lambda)},\end{aligned} \tag{8.30}$$

其中引入

$$\begin{aligned}G(Q,\lambda) &= -n\frac{\beta^2}{4}-\frac{\beta^2}{2}\sum_{a<b}Q_{ab}^p+\sum_{a<b}i\lambda_{ab}Q_{ab}\\ &\quad-\log\left[\sum_{\{\sigma^a\}}\exp\left(\sum_{a<b}i\lambda_{ab}\sigma^a\sigma^b\right)\right].\end{aligned} \tag{8.31}$$

它依赖 $n(n-1)/2+n(n-1)/2$ 个变量 Q_{ab},λ_{ab}，$1\le a<b\le n$。[6]

[6]译注：式 (8.30) 第一行的各 delta 因子在原排式仅写一个通式，译文显式写出对 $a<b$ 的乘积；末行省略的 $(N/2\pi)^{n(n-1)/2}$ 等前因子不改变固定整数 n 时的主导指数。以实 $\mu=i\lambda$ 求鞍点涉及轮廓的形式处理，并非自动给出了严格积分变形证明。

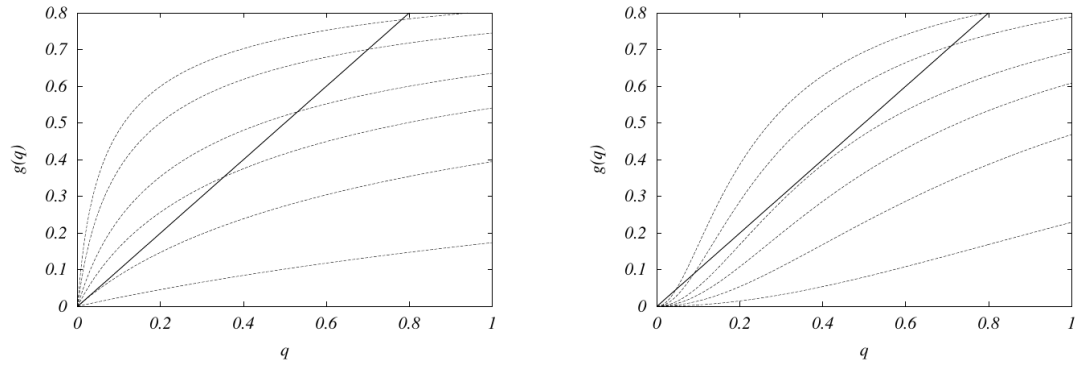


图 8.3: p 自旋模型 RS 方程的图解，$p=2$（左，SK 模型）与 $p=3$（右）。从上到下的曲线对应逆温度 $\beta=4,3,2,1.5,1,0.5$。取自 Part B PDF 第 64 页（原 156）。

习题 8.6. 另一条路线是注意到式 (8.28) 右侧仅通过重叠矩阵 $Q_{ab}=N^{-1}\sum_i \sigma_i^a\sigma_i^b$ $(a<b)$ 依赖构型。因此可将求和拆成对重叠矩阵及给定重叠矩阵下构型的求和：

$$\mathbb{E}Z^n \doteq \sum_{Q} \mathcal{N}_N(Q)\exp\left(\frac{N\beta^2}{4}n+\frac{N\beta^2}{2}\sum_{a<b}Q_{ab}^p\right). \tag{8.32}$$

$\mathcal{N}_N(Q)$ 为重叠矩阵是 Q 的自旋构型数。类似 *REM*，自然猜测 $\mathcal{N}_N(Q)\doteq\exp[Ns(Q)]$。用 *Gärtner–Ellis* 定理 *4.12* 求“熵”因子 $s(Q)$ 的表达式，并比较所得 $\mathbb{E}Z^n$ 与式 (8.28)。

按一般思路，用鞍点法估计大 N 时式 (8.30) 的积分。用 $\mu_{ab}=i\lambda_{ab}$ 表示驻点条件最为方便。对式 (8.31) 求导，得到对任意 $a<b$，

$$\mu_{ab}=\frac{1}{2}p\beta^2 Q_{ab}^{p-1}, \qquad\qquad Q_{ab}=\langle\sigma^a\sigma^b\rangle_n, \tag{8.33}$$

其中对任意 $f(\sigma)=f(\sigma^1,\dots,\sigma^n)$，定义复本化系统内的平均

$$\begin{aligned}\langle f(\sigma)\rangle_n &\equiv \frac{1}{z(\mu)}\sum_{\{\sigma^a\}} f(\sigma)\exp\left(\sum_{a<b}\mu_{ab}\sigma^a\sigma^b\right),\\ z(\mu) &\equiv \sum_{\{\sigma^a\}}\exp\left(\sum_{a<b}\mu_{ab}\sigma^a\sigma^b\right).\end{aligned} \tag{8.34}$$

先考虑 RS 鞍点：任意 $a\neq b$ 时 $Q_{ab}=q$、$\mu_{ab}=\mu$。利用高斯恒等式 (8.27)，鞍点方程变为

$$\mu=\frac{1}{2}p\beta^2 q^{p-1}, \qquad\qquad q=\mathbb{E}_z\tanh^2(z\sqrt{\mu}), \tag{8.35}$$

$\mathbb{E}_z$ 是对均值 0、方差 1 的高斯变量 z 的期望。消去 μ 得到 $q=r(q)$，其中

$$r(q)=\mathbb{E}_z\tanh^2\left(z\sqrt{p\beta^2q^{p-1}/2}\right).$$

图 8.3 绘出不同温度下 $p=2,3$ 的 $r(q)$。方程总有 $q=\mu=0$ 解，代入式 (8.31) 并用复本技巧 (8.2) 得

$$f_{\mathrm{RS}}=\lim_{n\to0}\frac{1}{\beta n}G(Q_{\mathrm{RS}},\lambda_{\mathrm{RS}})=-\frac{\beta}{4}-\frac{1}{\beta}\log 2. \tag{8.36}$$

温度足够低时，还会出现其他 RS 解。$p=2$ 时，$\beta_c=1$ 处单个非零解从 0 连续出现，见左图；$p\geq 3$ 时，一对非零解在 $\beta\geq\beta_*(p)$ 不连续出现，在 $\beta\downarrow\beta_*(p)$ 时合并，见右图。不过可用两个论据排除这些鞍点：

- 稳定性：在 RS 鞍点附近对 $G(Q,\lambda)$ 作 Taylor 展开。应用鞍点法要求二阶导数矩阵符号确定；附录所讨论的非零 RS 鞍点不满足该条件。

- 熵的非负性：如第 二章所述，具有离散自由度的物理系统因熵非负，自由能必须是温度的递减函数。也可证明非零 RS 鞍点不满足该条件。另一方面，温度足够低时 $q=0$ 鞍点也违反它，读者可从式 (8.36) 验证。*

这些论据十分一般，特别是第二项易于检查，正确鞍点必须满足。结论是低温时没有一个 RS 鞍点正确，因而转而寻找 1RSB 鞍点。将 n 个复本分成 n/m 个大小为 m 的组，取

$$\begin{aligned} &Q_{ab}=q_1,\quad \mu_{ab}=\mu_1, && \text{若 } a,b \text{ 属同组},\\ &Q_{ab}=q_0,\quad \mu_{ab}=\mu_0, && \text{若 } a,b \text{ 属不同组}. \end{aligned}\tag{8.37}$$

译注：式 (8.35) 是 $n\to 0$ 后的形式；有限整数 n 的单点平均还含 $\cosh^n$ 权重。原文关于 RS 分支的排除针对低温物理解，不应理解为所有温度、所有非零分支均违反所有条件；附录的局部稳定性也不保证全局主导性。离散熵非负给出 $df/dT\leq 0$，可有等号。

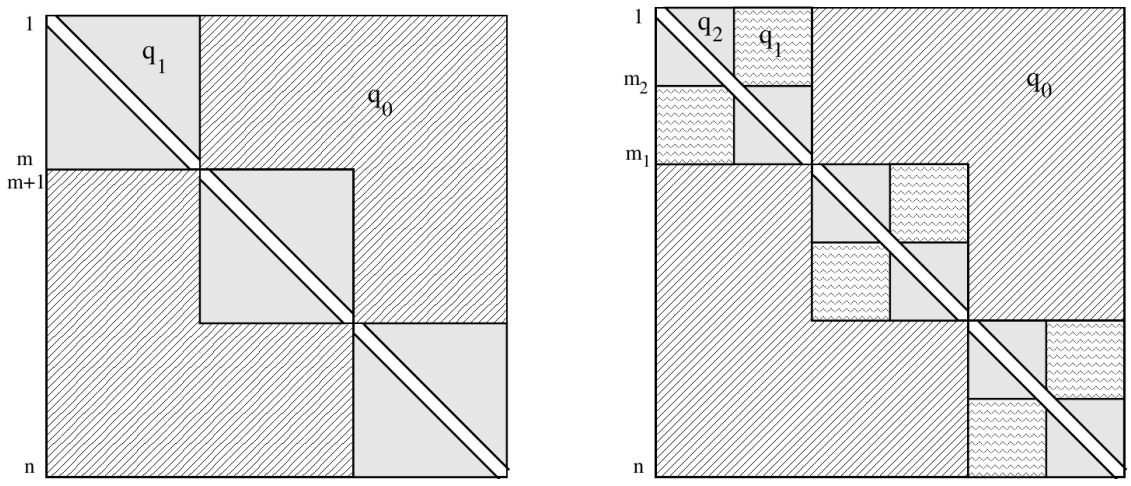


图 8.4: 复本对称性破缺时 Q_{ab} 的结构。左：1RSB 拟设，$n(n-1)/2$ 个 Q_{ab} 是 $n\times n$ 对称矩阵的非对角元。复本分成 n/m 个大小为 m 的块，同块时 $Q_{ab}=q_1$，否则 q_0。右：2RSB 拟设，示例取 $n/m_1=3$、$m_1/m_2=2$。取自 Part B PDF 第 66 页（原 158）。

可重排复本，使各组为连续指标 $\{1,\dots,m\}$、$\{m+1,\dots,2m\}$，直至 $\{n-m+1,\dots,n\}$，

见图 8.4。[7]在这一鞍点计算 G，反复用到式 (8.27)，留作练习。*结果为

$$\begin{aligned} G(Q^{\mathrm{1RSB}},\lambda^{\mathrm{1RSB}}) = &-n\frac{\beta^2}{4}+n\frac{\beta^2}{4}[(1-m)q_1^p+mq_0^p] \\ &-\frac{n}{2}[(1-m)q_1\mu_1+mq_0\mu_0]+\frac{n}{2}\mu_1 \\ &-\log\left\{\mathbb{E}_{z_0}\left[\mathbb{E}_{z_1}\left(2\cosh(\sqrt{\mu_0}z_0+\sqrt{\mu_1-\mu_0}z_1)\right)^m\right]^{n/m}\right\}. \end{aligned} \tag{8.38}$$

z_0, z_1 为独立的标准高斯变量，$\mathbb{E}_{z_0}, \mathbb{E}_{z_1}$ 为对应期望。

习题 8.7. 证明极限

$$G_{\mathrm{1RSB}}(q,\mu;m) = \lim_{n\to 0} n^{-1} G(Q^{\mathrm{1RSB}},\lambda^{\mathrm{1RSB}})$$

存在并求出它。对 $q_1, q_0, \mu_1, \mu_0, m$ 求偏导并令其为 0，确定驻点条件。证明方程总与 $q_0=\mu_0=0$ 相容，且

$$\begin{aligned} G_{\mathrm{1RSB}}\big|_{q_0,\mu_0=0} = &-\frac{1}{4}\beta^2[1-(1-m)q_1^p]+\frac{1}{2}\mu_1[1-(1-m)q_1] \\ &-\frac{1}{m}\log \mathbb{E}_z[(2\cosh(\sqrt{\mu_1}z))^m]. \end{aligned} \tag{8.39}$$

选取 $q_0=\mu_0=0$ 后，其余参数满足[8]

$$\mu_1 = \frac{1}{2}p\beta^2 q_1^{p-1}, \qquad q_1 = \frac{\mathbb{E}_z[(2\cosh(\sqrt{\mu_1}z))^m \tanh^2(\sqrt{\mu_1}z)]}{\mathbb{E}_z[(2\cosh(\sqrt{\mu_1}z))^m]}. \tag{8.40}$$

这些方程总有 $q_1=\mu_1=0$ 解，它实际上退回 RS 拟设，见式 (8.37)。现在考虑 $p\geq 3$。足够低温时出现两个非零解，局部稳定性分析表明应选较大的那个，记为 $\mu_1^{\mathrm{sp}}, q_1^{\mathrm{sp}}$。

下一步对 $m\in[0,1]$ 优化 $G_{\mathrm{1RSB}}(q^{\mathrm{sp}},\mu^{\mathrm{sp}};m)$；注意其对 m 既有显式依赖，也通过 $q^{\mathrm{sp}},\mu^{\mathrm{sp}}$ 隐式依赖。存在唯一驻点 $m_s(\beta)$，但仅在足够低温 $\beta>\beta_c(p)$ 时属于 $[0,1]$。$\beta_c(p)$ 的具体刻画参见文献。在临界温度处，1RSB 与 RS 自由能相等；系统从 $\beta<\beta_c(p)$ 的 RS 相转到 $\beta>\beta_c(p)$ 的 1RSB 相。

大 p 极限使计算大为简化，并可解析完成。展开的主导项为

$$\beta_c(p) = 2\sqrt{\log 2}+e^{-\Theta(p)}, \qquad m_s(\beta)=\frac{\beta_c(p)}{\beta}+e^{-\Theta(p)}, \qquad q_1 = 1-e^{-\Theta(p)}. \tag{8.41}$$

相应自由能密度在整个低温相中为常数 $-\sqrt{\log 2}$。可见大 p 极限恢复了 REM 的若干性质，下面的习题提供一些线索。[9]

习题 8.8. 对任意构型 σ，按式 (8.25) 随机选取耦合样本时，记其能量的概率密度为 $P_\sigma(E)$。证明它与 σ 无关，是均值 0、方差 $N/2$ 的高斯分布。再取两个构型 σ,σ'，证明随机样本中能量 E,E' 的联合分布为

$$P_{\sigma,\sigma'}(E,E') = C\exp\left[-\frac{(E+E')^2}{2N(1+x^p)}-\frac{(E-E')^2}{2N(1-x^p)}\right], \tag{8.42}$$

其中 $x=N^{-1}\sum_i \sigma_i\sigma_i'$，$C$ 为归一化常数。$|x|<1$ 时，两能量在 $p\to\infty$ 变为不相关，即 $P_{\sigma,\sigma'}(E,E')\to P_\sigma(E)P_{\sigma'}(E')$，提示类似 *REM* 的行为。

---

[7]原注：有些不同重排给出不同的 1RSB 鞍点，但 $G(Q,\lambda)$ 相同。这是 RSB 鞍点的一般特征，REM 的第 8.1.4 节已见过。

[8]原注：直接对式 (8.39) 的 q_1,μ_1 求导最方便。

[9]译注：此处常数自由能指所述大 p 极限的主导结果；不能由此声称每个有限 p 的整个低温相自由能完全相同。

译注： 这里 $P_\sigma(E)$ 是能量的概率密度，非单位自旋能量密度。方差 $N/2$ 与协方差 $(N/2)x^p$ 是固定 p 的大 N 主导值；有限 N 的方差恰为 $\binom{N}{p}p!/(2N^{p-1})$。$x=\pm1$ 时联合高斯可能退化，不适用普通二维密度。大 p 讨论须与大 N 极限的次序相容，不能在固定 N 直接取任意大的 p。

要判断刚得到的 1RSB 解是否正确，首先需检查 Hessian，即 G 对各变量二阶导数矩阵的特征值符号。原则上直接，但计算冗长，这里只给出 Elizabeth Gardner 的结果：1RSB 解仅在中间相 $\beta_c(p)<\beta<\beta_u(p)$ 稳定；$\beta_u(p)$ 处又相变到需要更复杂 RSB 方案的新相。

Parisi 将 1RSB 推广到更高阶，构造具有层级结构。定义两步破缺（2RSB）矩阵时，从图 8.4 左图出发，保持值为 q_0 的非对角块不变，改变对角块。将 m 改称 m_1，取任意 $m_1\times m_1$ 对角块；1RSB 中其矩阵元均为 q_1，2RSB 中再将这些复本分为 m_1/m_2 个大小 m_2 的组。非对角子块仍为 q_1，对角子块变成新值 q_2，见右图。矩阵由 q_0,q_1,q_2,m_1,m_2 五个数参数化。[10]

继续将 m_2 个复本分成 m_2/m_3 个大小 m_3 的组，即可推广。所谓*完全复本对称性破缺*（FRSB）是将过程迭代 R 次，最后取 $R\to\infty$。整数 n 时需 $n\geq m_1\geq\cdots\geq m_R\geq1$，而 $n\to0$ 时次序反转为 $0\leq m_1\leq\cdots\leq m_R<1$。给定 R 步拟设，计算率函数 G、求解鞍点方程便是微积分问题，$R\to\infty$ 时已有专门技巧。$\beta>\beta_u(p)$ 时必须用 FRSB 才能得到稳定解；SK 模型在整个 $\beta>1$ 相也如此，详述则超出本章范围。

8.2.2 重叠分布

此前 RSB 作为计算配分函数的形式技巧出现。自旋玻璃理论一个迷人特点是，它有具体的物理和概率解释。出现 RSB 的系统，其典型样本中有一些自旋构型与最低能量的基态构型相差很大，但能量十分接近。构型间重叠的分布可衡量这一性质。给定 $\sigma=\{\sigma_1,\ldots,\sigma_N\}$、$\sigma'=\{\sigma'_1,\ldots,\sigma'_N\}$，定义

$$q_{\sigma\sigma'}=\frac{1}{N}\sum_{i=1}^{N}\sigma_i\sigma'_i, \tag{8.43}$$

故 $N(1-q_{\sigma\sigma'})/2$ 是 Hamming 距离。对记为 J 的一个固定样本，*重叠分布* $P_J(q)$ 是依 Boltzmann 分布独立选取的两个构型之重叠的概率密度：

$$\int_{-1}^{q}P_J(q')\,dq'=\frac{1}{Z^2}\sum_{\sigma,\sigma'}e^{-\beta E(\sigma)-\beta E(\sigma')}\mathbb{I}(q_{\sigma\sigma'}\leq q). \tag{8.44}$$

用复本计算其热力学极限的样本平均

$$P(q)\equiv\lim_{N\to\infty}\mathbb{E}P_J(q). \tag{8.45}$$

得到

$$\int_{-1}^{q}P(q')\,dq'=\lim_{n\to0}\sum_{\sigma^1,\ldots,\sigma^n}\mathbb{E}\left[\exp\left(-\beta\sum_a E(\sigma^a)\right)\right]\mathbb{I}(q_{\sigma^1\sigma^2}\leq q). \tag{8.46}$$

译注： 有限 N 时重叠是离散变量，“密度”须按含 delta 原子的概率测度理解，积分约定包含边界原子；上述公式仍隐含本章的大 N 与复本极限。原式 (8.46) 的 $E(\sigma^a)$ 少一个右括号，译文仅配平括号。

[10]译注：此段“均为”始终针对非对角元；原自旋重叠的对角元 $Q_{aa}=1$ 不随分块改变。

计算与 $\mathbb{E}Z^n$ 相似，区别只是要求复本 1、2 的重叠不超过 q。同样步骤给出用鞍点矩阵 Q^{sp}_{ab} 表示的结果。需注意：复本指标置换可能关联多个 RSB 鞍点。若 Q 为鞍点，则任意 $\pi \in S_n$ 得到的 $Q^{\pi}_{ab} = Q_{\pi(a)\pi(b)}$ 也是等权鞍点，$G(Q^{\pi}) = G(Q)$。计算 $P(q)$ 时须加上全部不同的等价鞍点，最终得到

$$\int_{-1}^{q} P(q')\,dq' = \lim_{n\to 0} \frac{1}{n(n-1)} \sum_{a\neq b} \mathbb{I}(Q^{\mathrm{sp}}_{ab} \le q). \tag{8.47}$$

RS 解时

$$\int_{-1}^{q} P(q')\,dq' = \mathbb{I}(q^{\mathrm{RS}} \le q), \tag{8.48}$$

其中 q^{RS} 满足式 (8.35)。即依 Boltzmann 分布抽两个构型，其重叠高概率为 q^{RS}。重叠是许多“简单” 项的和，分布集中在典型值附近也算自然。

对于由 $q_0, q_1, \lambda_0, \lambda_1, m$ 描述的 1RSB 相，则有

$$\int_{-1}^{q} P(q')\,dq' = (1-m)\mathbb{I}(q_1 \le q) + m\mathbb{I}(q_0 \le q). \tag{8.49}$$

重叠以有限概率取 q_0 或 q_1，具有漂亮的几何解释：在 $\beta > \beta_c(p)$ 依 Boltzmann 概率抽样时，典型构型分成若干簇；同簇内两构型重叠为 q_1，异簇间为 $q_0 < q_1$，Hamming 距离更大。随机抽两个构型落入同簇的概率为 $1-m$。这种分簇性质相当非平凡，若没有详细计算很难预见；后面还会遇到其他模型。尽管这里的复本推导不严格，分簇现象本身可以严格证明。

更高阶 RSB 时 $P(q)$ 出现更多峰。几何上，簇内含子簇，子簇又含子簇，依此类推。层级结构导出超度量性：独立依 Boltzmann 分布抽三个构型，以 Hamming 距离为三边，则高概率得到等边三角形，或两腰比底边长的等腰三角形。完全 RSB 时 $P(q)$ 含连续部分，簇不再良好分离，分簇性质变得不那么鲜明，但超度量性仍成立。[11]

习题 8.9. *对 1RSB 相中的给定样本，定义 Y 为两个构型落入同簇的概率；确切地，$Y = \int_q^1 P_J(q')\,dq'$，其中 $q_0 < q < q_1$。上面的分析给出 $\lim_{N\to\infty}\mathbb{E}Y = 1-m$。证明大 N 时与 REM 一样，$\mathbb{E}(Y^2) = (3-5m+2m^2)/3$；证明 Y 的全部矩均与 REM 相同。结果仅依赖鞍点的 1RSB 结构，不依赖细节。*

8.3 极值统计与 REM

习题 8.9 提示，玻璃相中有独立于模型细节的普适性质。对于有 1RSB 相的系统，这与极值统计的普适性有关。为说明这一点，本节考虑稍广义的 REM：$M = 2^N$ 个能级独立同分布，概率密度 $P(E)$ 满足

1. $P(E)$ 连续；

2. 在半无限区间 $-\infty < E \le E_0$ 上严格为正；

[11] 译注：零外场且具有全局自旋翻转对称性的模型，直接对完整 Gibbs 测度抽样还需处理对称扇区及负重叠。此处单个非负重叠分支的图景按原稿保留，不应默认为有限 N 全对称测度的完整分布。

3. $E \to -\infty$ 时，比任何幂律都更快地趋于 0。这里只讨论简单情形

$$P(E) \simeq A\exp(-B|E|^{\delta}) \qquad (E \to -\infty), \tag{8.50}$$

其中 A, B, δ 为正常数。

允许这样一般的分布，是为了检验对应 REM 的哪些性质普适。

第 五章已见，REM 低温相受少数低能级控制。先求 $E_1, \ldots, E_M$ 中最低能级 E_{gs} 的分布。显然

$$\mathbb{P}[E_{\mathrm{gs}} > E] = \left[\int_E^{\infty} P(x)\,dx\right]^M. \tag{8.51}$$

令 $E^*(M)$ 满足单个能级的 $\mathbb{P}[E_i < E^*(M)] = 1/M$。$M \to \infty$ 时

$$|E^*(M)|^{\delta} = \frac{\log M}{B} + O(\log\log M). \tag{8.52}$$

聚焦于 $E = E^*(M) + \varepsilon/(B\delta|E^*(M)|^{\delta-1})$，固定 ε 取 $M \to \infty$，则

$$\begin{aligned}\mathbb{P}[E_i > E] &= 1 - \frac{A}{B\delta|E|^{\delta-1}} e^{-B|E|^{\delta}}[1 + o(1)] \\ &= 1 - \frac{1}{M}e^{\varepsilon}[1 + o(1)].\end{aligned} \tag{8.53}$$

以 $E_{\mathrm{gs}} = E^*(M) + \varepsilon_{\mathrm{gs}}/(B\delta|E^*(M)|^{\delta-1})$ 定义缩放基态能量，得到

$$\lim_{N\to\infty} \mathbb{P}[\varepsilon_{\mathrm{gs}} > \varepsilon] = \exp(-e^{\varepsilon}). \tag{8.54}$$

即缩放基态能量的概率密度收敛到 $P_1(\varepsilon) = \exp(\varepsilon - e^{\varepsilon})$。这一称为 Gumbel 分布的极限分布是普适的：原能级分布的形式只影响平移与尺度，不影响 P_1 的形式。下面的习题还表明 REM 玻璃相的若干其他性质也普适。[12]

习题 8.10. 令 $E_1 \le E_2 \le \cdots \le E_k$ 为最低的 k 个能量。证明固定 k、$M \to \infty$ 时，其联合分布也普适。具体地，令 $E_i = E^*(M) + \varepsilon_i/(B\delta|E^*(M)|^{\delta-1})$，定义 $\varepsilon_1 \le \cdots \le \varepsilon_k$。证明其联合密度收敛到

$$P_k(\varepsilon_1, \ldots, \varepsilon_k) = \exp(\varepsilon_1 + \cdots + \varepsilon_k - e^{\varepsilon_k})\mathbb{I}(\varepsilon_1 \le \cdots \le \varepsilon_k). \tag{8.55}$$

习题 8.11. 考虑能量概率密度满足上述三条假设的 *REM*，$M = 2^N$。证明：要使基态能量具有广延性，即大 N 时 $E_1 \sim N$，必须有 $B \sim N^{1-\delta}$。证明系统在临界温度 $T_c = \delta(\log 2)^{(\delta-1)/\delta}$ 处相变。

定义参与比 $Y_r \equiv \sum_{j=1}^{2^N} p_j^r$，证明 $T < T_c$ 时它表征凝聚现象。更确切地，

$$\lim_{N\to\infty} \mathbb{E}Y_r = \frac{\Gamma(r-m)}{\Gamma(r)\Gamma(1-m)}, \tag{8.56}$$

其中 $m = (T/T_c)\min\{\delta, 1\}$，如标准 *REM*（原文引“第 *8.3* 节”）。提示：可用第 *5.3* 节的方法作直接概率证明；$\delta > 1$ 时也可用第 *8.1.4* 节复本方法。

[12]译注：这里是基态能量随机变量的概率密度，不是单位自旋能量；式 (8.52) 至 (8.54) 首先针对固定尾分布取 $M \to \infty$。若 A, B 随 N 变化，还需相应的一致尾渐近条件。

译注：原习题的 T_c、m 和节号照录，不将其认证为无条件结论。仅有 $B \sim N^{1-\delta}$ 不能固定临界温度的数值，尚依赖比例系数。即使取 $B = N^{1-\delta}$，在 $\delta > 1$、相应大偏差尾有效时，由 $s(e) = \log 2 - |e|^{\delta}$ 得到的是 $\beta_c = \delta(\log 2)^{(\delta-1)/\delta}$，不是所写的 T_c；$\delta = 2$ 已与标准 REM 温度不符。$\delta \le 1$ 的非凸或边界情形需另行处理。Gamma 矩公式还需 $r > m$ 等条件，不从给定三条尾条件直接保证全部热力学结论。

凝聚相只有低能构型起作用；其分布的普适性导致 Boltzmann 概率 p_j 各阶矩普适。1RSB 也捕捉到这些普适性质，解释了它为何能成功用于许多具有玻璃相的系统。

一个自然且引人入胜的假设是，更高阶 RSB 对应相关变量极值统计的不同普适类。据我们所知，数学文献尚未研究这些普适类的数学定义。[13]

8.4 附录：RS 鞍点的稳定性

判断复本鞍点是否正确时，广泛采用的一个标准是局部稳定性。为解释基本思路，先退一步，仅用重叠参数表示复本化自由能：

$$\mathbb{E}Z^n \doteq \sum_{Q} e^{N\widehat{G}(Q)}. \tag{8.57}$$

它既可从式 (8.30) 对 $\{\lambda_{ab}\}$ 积分得到，也可按习题 8.6 的路线推导。后一方法给出

$$\widehat{G}(Q) = -n\frac{\beta^2}{4} - \frac{\beta^2}{2}\sum_{a<b} Q_{ab}^{p} - s(Q), \tag{8.58}$$

其中

$$\begin{aligned} s(Q) &= -\sum_{a<b}\mu_{ab}Q_{ab} + \psi(\mu)\Big|_{\mu=\mu^*(Q)}, \\ \psi(\mu) &= \log\left[\sum_{\{\sigma^a\}} \exp\left(\sum_{a<b}\mu_{ab}\sigma^a\sigma^b\right)\right], \end{aligned} \tag{8.59}$$

$\mu^*(Q)$ 解方程 $Q_{ab} = \partial\psi(\mu)/\partial\mu_{ab}$。除整体负号外，$s$ 是 ψ 的 Legendre 变换。虽无 $s(Q)$ 的显式表达式，但只需用到 Legendre 变换的熟知性质

$$\frac{\partial^2 s(Q)}{\partial Q_{ab}\partial Q_{cd}} = -C^{-1}_{(ab)(cd)}, \qquad C_{(ab)(cd)} \equiv \left.\frac{\partial^2\psi(\mu)}{\partial\mu_{ab}\partial\mu_{cd}}\right|_{\mu=\mu^*(Q)}, \tag{8.60}$$

C^{-1} 为矩阵逆。用复本系统内平均（式 (8.34)）容易写成

$$C_{(ab)(cd)} = \langle\sigma^a\sigma^b\sigma^c\sigma^d\rangle_n - \langle\sigma^a\sigma^b\rangle_n\langle\sigma^c\sigma^d\rangle_n. \tag{8.61}$$

设 $(Q^{\mathrm{sp}}, \lambda^{\mathrm{sp}})$ 为 G 的驻点，等价于 Q^{sp} 为 $\widehat{G}$ 的驻点，相应 $\mu = i\lambda^{\mathrm{sp}}$。希望用 $\mathbb{E}Z^n \doteq e^{N\widehat{G}(Q^{\mathrm{sp}})}$ 估计式 (8.57)，必要条件是 $\widehat{G}$ 在该点的二阶导数矩阵半正定，称为*局部稳定性条件*。由式 (8.58)、(8.61) 得

$$M_{(ab)(cd)} \equiv -\frac{1}{2}\beta^2 p(p-1)Q_{ab}^{p-2}\delta_{(ab),(cd)} + C^{-1}_{(ab)(cd)} \succeq 0, \tag{8.62}$$

[13]译注：保留作者草稿当时的假设与知识状态，不将其提升为定理或当前文献结论。

其中 $A \succeq 0$ 表示 A 半正定。**译注：** 原式 (8.57) 及后文的指数均写正号，但式 (8.58) 与此前 e^{-NG} 的约定一致；若采用这里的 $\widehat{G}$ 定义，应为 $e^{-N\widehat{G}}$，才与极小值及 Hessian 半正定相容。译文保留原符号并提示矛盾。式 (8.60) 还隐含局部可微、C 可逆等条件，边界需另行处理。局部稳定性只是必要的自洽检查，不证明物理解或全局主导性。

本技术附录在两个简单情形概述计算：零场一般 p 自旋玻璃的 RS 鞍点，以及有场 SK 模型。先取 $Q_{ab} = \lambda_{ab} = 0$，此时

$$\langle f(\sigma)\rangle_n = \frac{1}{2^n}\sum_{\{\sigma^a\}} f(\sigma). \tag{8.63}$$

容易得到 $p \geq 3$ 时 $M_{(ab)(cd)} = \delta_{(ab),(cd)}$，$p = 2$ 时为 $(1-\beta^2)\delta_{(ab),(cd)}$。二者非常不同：

- $p = 2$（SK 模型）：RS 解在 $\beta < 1$ 稳定，$\beta > 1$ 不稳定。
- $p \geq 3$：RS 解始终稳定。

再看磁场中的 SK 模型，即 $p = 2$，但在式 (8.24) 的能量中加 $-B\sum_i \sigma_i$。重复复本计算很直接。⋆只需将复本系统内平均改成

$$\langle f(\sigma)\rangle_{n,B} \equiv \frac{1}{z(\mu)}\sum_{\{\sigma^a\}} f(\sigma)\exp\left(\sum_{a<b}\mu_{ab}\sigma^a\sigma^b + \beta B\sum_a \sigma^a\right), \tag{8.64}$$

$$z(\mu) \equiv \sum_{\{\sigma^a\}} \exp\left(\sum_{a<b}\mu_{ab}\sigma^a\sigma^b + \beta B\sum_a \sigma^a\right), \tag{8.65}$$

形式上结果与此前相同。RS 鞍点方程变为

$$\mu = \beta^2 q, \qquad\qquad q = \mathbb{E}_z \tanh^2(z\sqrt{\mu} + \beta B). \tag{8.66}$$

$B \neq 0$ 时任意正 β 都有非零 q, μ，稳定性分析更复杂。

$p = 2$ 时，$M_{(ab)(cd)} = -\beta^2\delta_{(ab)(cd)} + C^{-1}_{(ab)(cd)}$。令 $\{\lambda_j\}$ 为 C 的特征值。由于 $C \succeq 0$，$M \succeq 0$ 等价于所有 j 都有 $1 - \beta^2\lambda_j \geq 0$。$C$ 的矩阵元依无序对 $(ab), (cd)$ 共同指标数分成三种：

$$\begin{aligned}
C_{(ab)(ab)} &= 1 - [\mathbb{E}_z \tanh^2(z\sqrt{\mu} + \beta B)]^2 \equiv U,\\
C_{(ab)(ac)} &= \mathbb{E}_z \tanh^2(z\sqrt{\mu} + \beta B) - [\mathbb{E}_z \tanh^2(z\sqrt{\mu} + \beta B)]^2 \equiv V,\\
C_{(ab)(cd)} &= \mathbb{E}_z \tanh^4(z\sqrt{\mu} + \beta B) - [\mathbb{E}_z \tanh^2(z\sqrt{\mu} + \beta B)]^2 \equiv W.
\end{aligned}$$

第二行假设 $b \neq c$，最后一行所有指标互异。求特征方程 $\sum_{(cd)} C_{(ab)(cd)}x_{cd} = \lambda x_{(ab)}$。

首个特征向量是均匀向量 $x_{(ab)} = x$，特征值 $\lambda_1 = U + 2(n-2)V + (n-2)(n-3)W/2$。再取依赖一个特殊指标 θ 的向量：若 $a = \theta$ 或 $b = \theta$，则 $x_{(ab)} = x$；其他情形为 y。选择 $x = (1 - n/2)y$ 保证与均匀向量正交，得到 $\lambda_2 = U + (n-4)V + (3-n)W$，简并度为 $n-1$。最后考虑依赖两个特殊指标 θ, ν 的向量：$x_{(\theta,\nu)} = x$、$x_{(\theta,a)} = x_{(\nu,a)} = y$、$x_{(ab)} = z$，其中 a, b 不等于 θ, ν。与前述向量正交要求 $x = (2-n)y$、$y = [(3-n)/2]z$。代入得到 $\lambda_3 = U - 2V + W$，简并度 $n(n-3)/2$。

$n\to 0$ 时只有两个不同特征值：$\lambda_1=\lambda_2=U-4V+3W$、$\lambda_3=U-2V+W$。由于 $V\ge W$，最危险的是 λ_3，称为 *replicon* 特征值。因此 SK 模型的 RS 解局部稳定，当且仅当

$$\mathbb{E}_z[1-\tanh^2(z\sqrt{\mu}+\beta B)]^2\le T^2. \tag{8.67}$$

等号在 (T,B) 平面的 AT 线上成立。$B\to 0$ 时它表现为 $T=1-(3/4)^{2/3}B^{2/3}+o(B^{2/3})$，$B\gg 1$ 时为 $T\simeq 4e^{-B^2/2}/(3\sqrt{2\pi})$。**译注：**本段是将整数复本空间的谱形式延拓到 $n\to 0$，不将负的形式简并度理解为实际负维线性空间。式 (8.67) 表示先平方再取 $\mathbb{E}_z$，即 $\mathbb{E}_z\operatorname{sech}^4(z\sqrt{\mu}+\beta B)$。原小场展开的系数指数 2/3 照录；按这里的 SK 归一化，标准小场关系 $B^2\sim\frac{4}{3}(1-T)^3$ 对应系数 $(3/4)^{1/3}$，与原文不一致；独立审阅者已按同一自洽式和 AT 条件展开核实这一差异。$p\ge 3$ 的零重叠解虽局部稳定，仍可能在低温被其他相取代。

习题 8.12. *为检验对复本计算的理解，研究零场 $B=0$、耦合有铁磁偏置的 SK 模型：J_{ij} 独立同分布为均值 J_0/N、方差 $1/N$ 的高斯变量。*

1. *证明 RS 方程变为*

$$\begin{aligned}&\mu=\beta^2 q, &&q=\mathbb{E}_z\tanh^2(z\sqrt{\mu}+\beta J_0 m),\\ &m=\mathbb{E}_z\tanh(z\sqrt{\mu}+\beta J_0 m).\end{aligned} \tag{8.68}$$

2. *数值求解。注意依 T,J_0 可有三类解：顺磁解 $m=q=0$，铁磁解 $m>0,q>0$，自旋玻璃解 $m=0,q>0$。*

3. *证明 AT 稳定性条件为*

$$\mathbb{E}_z[1-\tanh^2(z\sqrt{\mu}+\beta J_0 m)]^2<T^2, \tag{8.69}$$

并推出前两项找到的 RS 解仅在顺磁相及部分铁磁相稳定。

译注：本习题 m 指磁化强度，不是前文 1RSB 的分块参数；原文此处用严格小于，而式 (8.67) 用小于等于，分别须区分严格稳定与边界的半正定情形。零场铁磁有对称的负磁化分支，原题只列正分支。

注释

REM 的复本解来自 Derrida 引入该模型的原始工作（Derrida，1980；Derrida，1981）；其动机实际来自 p 自旋玻璃的大 p 极限。矩问题可参见 Shohat 和 Tamarkin（1943）。

第一个得到普遍接受的自旋玻璃模型由 Edwards 和 Anderson（1975）提出。Sherrington 和 Kirkpatrick 定义了平均场理论，并考虑 RS 解（Sherrington 和 Kirkpatrick，1975；Kirkpatrick 和 Sherrington，1978）。de Almeida 和 Thouless（1978）发现其在 $p=2$ 时的不稳定性，并首次计算了 AT 线。习题 8.12 的解可在 Kirkpatrick 和 Sherrington（1978）、de Almeida 和 Thouless（1978）找到。

Parisi 拟设始于 1979 年的几篇富于洞见的工作（Parisi，1979；Parisi，1980b；Parisi，1980a）。其最初动机是思考 $n<1$、特别是 $n\to 0$ 时置换群 S_n 的含义。遗憾的是，沿此方向尚无数

学进展；有 RSB 的复本方法仍在等待适当的数学框架。另一方面，它是定义明确、适用于广泛问题的计算方案。Parisi（1983）发现以凝聚解释 RSB 的物理含义，Mézard、Parisi、Sourlas、Toulouse 和 Virasoro（1985）进一步讨论了玻璃相中的权重分布及其超度量组织。Gross 和 Mézard（1984）用复本分析大 p 的模型，并在该工作中发现分簇现象；Gardner（1985）随后研究了有限 p。Talagrand（2000）对 p 自旋玻璃的分簇效应作了严格处理，其书 Talagrand（2003）也有论述。

Bouchaud 和 Mézard（1997）讨论 1RSB 与 Gumbel 极值统计的联系。更详细的复本方法介绍及上述许多论文的重印，见 Mézard、Parisi 和 Virasoro（1987）。[14]

[14]译注：本节文献保留作者—年份标识，可唯一匹配者已连接至 Part F；“尚无”等历史表述只对应所选草稿年代。

第九章　因子图与图系综

许多科学领域反复遇到由大量简单变量构成、变量间有相互依赖、约束或相互作用的系统。这些依赖往往能以非平凡方式“因子分解”，不同变量仅“局部”相互作用。在统计物理中，这源于物理相互作用的局域性；在计算机视觉中，源于视网膜的二维性质及重建规则的局域性；在编码理论中，则是设计快速编码、解码算法的一项有用性质。这种重要结构在许多问题中起关键作用。

用图表达随机变量依赖结构的方式有很多：无向或有向图模型、Bayes 网络、依赖图、正规实现等。本书因其简单灵活，采用因子图语言。

如前几章所论，我们特别关心概率分布的*系综*。它们可来自纠错码系综、无序材料，或随机组合优化问题。系综中的问题由随机因子图表示，最常见的是熟知随机图的简单推广——随机超图。

第 9.1 节介绍因子图并给出应用示例；第 9.2 节定义标准随机图及超图系综；第 9.3 节概述若干重要性质。边数越过阈值时，“巨型”连通分支突然出现，是随机图的一个惊人现象，第 9.4 节专门讨论。最后，第 9.5 节描述大型随机因子图的局部结构。

9.1　因子图

9.1.1　定义与一般性质

先看一个玩具例子。

例 9.1. 某国按一种特殊制度从候选人 $\{A,B\}$ 中选总统。全国分成四个地区 $\{1,2,3,4\}$，组成北州（*1*、*2*）和南州（*3*、*4*）。各地区普选支持的候选人记为 $x_i\in\{A,B\}$。北州候选人 y_N 按如下规则决定：若 $x_1=x_2$，取这一共同值；否则抛公平硬币。南州根据 x_3,x_4 同样决定 y_S，最终总统 z 根据 y_N,y_S 按同样规则决定。

民调机构已较好地估计各地区 i 支持 x_i 的概率 $p_i(x_i)$，请你计算各候选人当选总统的概率。上述过程有明显的因子分解性质，具体为

$$P(\{x_i\},\{y_j\},z)=f(z,y_N,y_S)f(y_N,x_1,x_2)f(y_S,x_3,x_4)\prod_{i=1}^{4}p_i(x_i). \tag{9.1}$$

请读者写出 f 的显式形式。*选举过程及分布可表示为图 *9.1*，计算当选概率时能否利用这种结构？

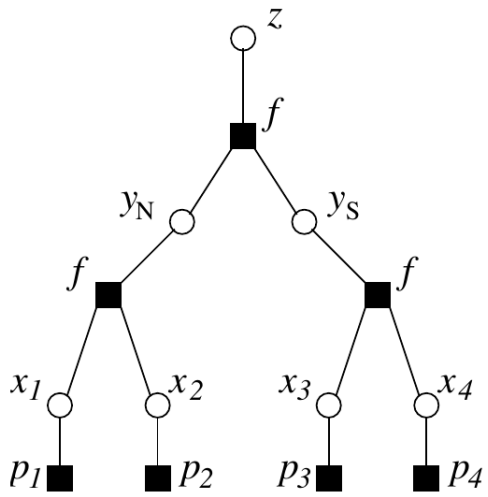


图 9.1: 例 9.1 的选举过程的因子图表示。取自 Part C PDF 第 2 页（原 170）。

从该例抽象出 N 个取值于有限字母表 $\mathcal{X}$ 的变量 $x_1, \dots, x_N$，假设联合分布为

$$P(x) = \frac{1}{Z} \prod_{a=1}^{M} \psi_a(x_{\partial a}). \tag{9.2}$$

这里 $x \equiv \{x_1, \dots, x_N\}$，$x_{\partial a} \equiv \{x_i : i \in \partial a\}$，$\partial a \subseteq [N]$。对 $a \in [M]$，令 $k_a = |\partial a|$；必要时以 $\{i_1^a, \dots, i_{k_a}^a\} \equiv \partial a$ 及 $x_{i_1^a, \dots, i_{k_a}^a} \equiv x_{\partial a}$ 表示指标及变量。相容函数 $\psi_a : \mathcal{X}^{k_a} \to \mathbb{R}$ 非负，Z 为正常数。完整确定分布，须给出各函数及 ∂a 中指标的次序，后者通常由上下文明确。

因子图是式 (9.2) 的图表示，有两类节点：N 个变量节点以圆圈表示，各对应 x_i；M 个函数节点以方块表示，各对应 ψ_a。若 $i \in \partial a$，即 x_i 为 ψ_a 的自变量，便连边 $i - a$。与变量 i 相邻的函数节点集合记为 ∂i。图是二部图，每条边总连接一个变量节点与一个函数节点。读者容易验证图 9.1 确实对应式 (9.1)。⋆变量节点的度即相接边数，可以任意；函数节点的度总不小于 1。

这种表示编码的基本性质是，两个“充分分离”的变量仅通过介于其中的变量相互作用。精确表述是*全局 Markov 性质*：

命题 9.2. *设 $A, B, S \subseteq [N]$ 为三个互不相交的变量节点子集，x_A, x_B, x_S 为相应变量。若 S“分离”A, B，即图上任何连接 A 中节点与 B 中节点的路径都经过 S，则*

$$P(x_A, x_B \mid x_S) = P(x_A \mid x_S) P(x_B \mid x_S). \tag{9.3}$$

称 x_A, x_B 条件独立。

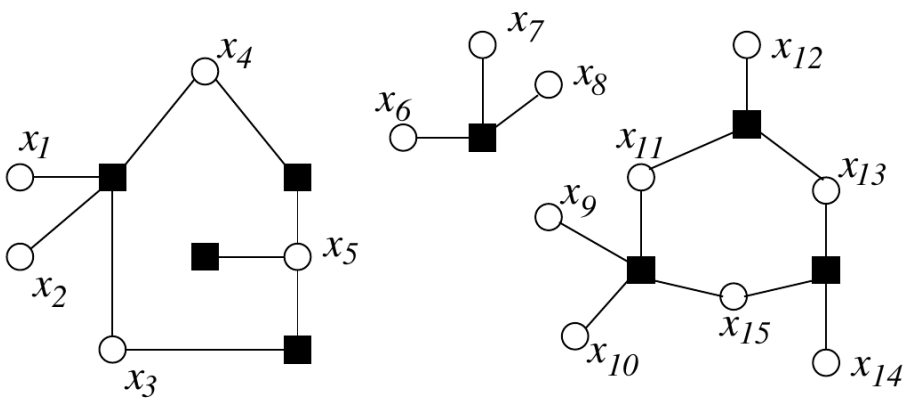


图 9.2: 一般因子图由若干连通分支组成。不同分支中的变量，如这里的 x_3, x_{15}，统计独立。取自 Part C PDF 第 3 页（原 171）。

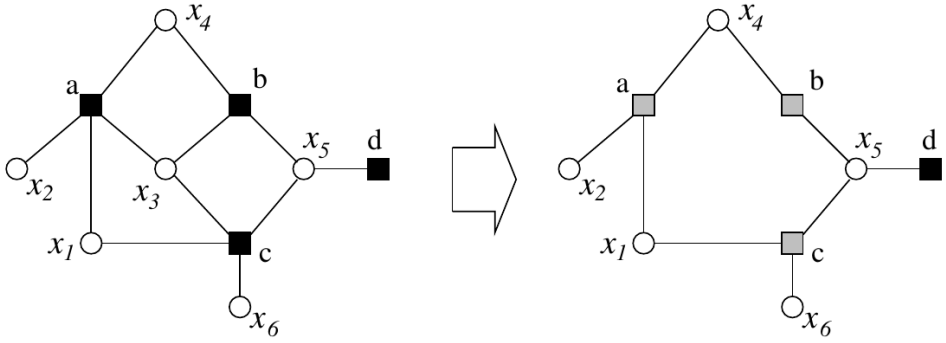


图 9.3: 条件化对因子图的作用。左图分布 $P(x_{1\ldots6}) \propto f_a(x_{1\ldots4}) f_b(x_{3,4,5}) f_c(x_{1,3,5,6}) f_d(x_5)$。给定 $x_3 = x_*$ 后，$P(x_{1\ldots6} \mid x_3 = x_*) \propto f'_a(x_{1,2,4}) f'_b(x_{4,5}) f'_c(x_{1,5,6}) f_d(x_5)$。右图灰节点的 f'_a, f'_b, f'_c 不同于原函数，并依赖 x_*。取自 Part C PDF 第 4 页（原 172）。

证明. 可作 “图解” 证明。图不连通时，不同分支的变量独立，见图 9.2。给定 x_i 等价于从图中删去该变量节点，并相应修改邻接函数，见图 9.3。给定 x_S 后，图被拆开，A, B 属于不同分支。细节留给读者。* □

译注： 条件分布限定于 $P(x_S) > 0$ 的条件值。相容函数允许为 0，但要求归一化常数 $Z = \sum_x \prod_a \psi_a(x_{\partial a}) > 0$。选举例式 (9.1) 还隐含各地区输入和所用硬币按该生成模型独立。

自然会问，任何对给定图满足全局 Markov 性质的分布，是否都能写成式 (9.2)? 一般不能。图 9.4 是简单例子，全局 Markov 性质只有取 $A = \{1\}$、$B = \{2, 3\}$、$S = \{4\}$ 时有非平凡内容。给定 x_4，x_1 与 $\{x_2, x_3\}$ 独立的最一般分布形如 $f_a(x_1, x_2) f_b(x_2, x_3, x_3)$。图所编码的分布是特殊情形，要求 $f_b(x_2, x_3, x_4) = f_c(x_2, x_3) f_d(x, x_4) f_e(x_4, x_2)$。**译注：** 该段原自变量有明显笔误，逐项保留。相应条件独立的一般形式应为 $f_a(x_1, x_4) f_b(x_2, x_3, x_4)$；三角形上的成对分解应含 $f_d(x_3, x_4)$，原 x 未定义。

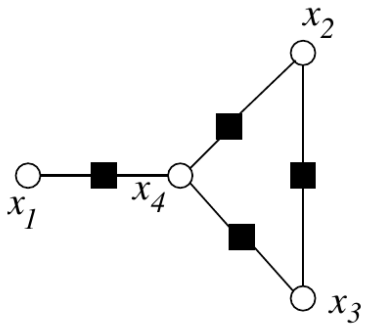


图 9.4: 四变量因子图。给定 x_4，$\{x_1\}$ 与 $\{x_2, x_3\}$ 独立。变量 $\{x_2, x_3, x_4\}$ 及连接其中两点的三个函数节点组成团。取自 Part C PDF 第 5 页（原 173）。

此反例有个特征：变量 $\{x_2, x_3, x_4\}$ 构成的子图中，任意两个变量都有共同的相邻函数节点，称这种因子子图为团。[1]排除这种障碍便可证明命题 9.2 的逆命题。具体用图的补全：对 F 中每个团加入一个函数节点，只连接团内全部变量；若已有这种节点则不重复。补全图记为 $\overline{F}$。

定理 9.3 (Hammersley–Clifford)**.** *设 P 是 $x \in \mathcal{X}^N$ 上严格为正的概率分布，关于因子图 F 满足全局 Markov 性质 (9.3)，则 P 可相对于补全图 $\overline{F}$ 写成式 (9.2) 的分解形式。*

粗略地说，因子分解背后唯一的假设，是全局 Markov 性质编码的相当弱的局域性。这为研究可因子分解的分布提供一般理由。严格正性 $P(x) > 0$ 不只是技术假设：允许概率为 0 时有反例。[2]

9.1.2 例子

再看几个例子。

例 9.4. *取值于有限状态空间 $\mathcal{X}$ 的 $X_1, \dots, X_N$ 构成 r 阶 Markov 链（$r < N$），若*

$$P(x_1, \dots, x_N) = P_0(x_1, \dots, x_r) \prod_{t=r}^{N-1} w(x_{t-r+1}, \dots, x_t \to x_{t+1}), \tag{9.4}$$

其中转移概率非负，且

$$\sum_{x_1,\dots,x_r} P_0(x_1, \dots, x_r) = 1, \qquad \sum_{x_0} w(x_{-r}, \dots, x_{-1} \to x_0) = 1. \tag{9.5}$$

r 为“记忆范围”。普通 Markov 链是 $r = 1$；更高阶可描述更复杂现象。例如，用通常的 $\mathcal{X} = \{\mathrm{a}, \mathrm{b}, \dots, \mathrm{z}, \text{空格}\}$ 模拟英语，合理模型大概需要典型词长的记忆（$r \geq 6$）。

式 (9.4) 显然是因子分解的特例，对应 N 个变量节点、$N - r$ 个转移因子节点、一个初始分布节点。图 9.5 给出 $N = 6, r = 2$ 的例子。记忆 r、状态空间 $\mathcal{X}$ 的链总可改写为状态空间 $\mathcal{X}^r$ 上的一阶链，新转移概率为

$$\widehat{w}(\vec{x} \to \vec{y}) = \begin{cases} w(x_1, \dots, x_r \to y_r), & x_2 = y_1, \dots, x_r = y_{r-1}, \\ 0, & \text{否则}, \end{cases} \tag{9.6}$$

[1]原注：通常图论中的 clique 指普通图中的团，这里将同一词稍作推广用于因子图。

[2]译注：逆命题中的正性与补全不可省略；这不否定原非负因子分布所满足的正向 Markov 性质。

其中 $\vec{x}=(x_1,\dots,x_r)$、$\vec{y}=(y_1,\dots,y_r)$，图 9.5 用因子图表示这种约化。

Markov 链的全局 *Markov* 性质是什么？一阶时取 $S=\{i\}$，A,B 分别为左右节点，原文写为 $A=\{1,\dots,r-1\}$、$B=\{r+1,\dots,N\}$，于是

$$P(x_1,\dots,x_N\mid x_i)=P(x_1,\dots,x_{i-1}\mid x_i)P(x_{i+1},\dots,x_N\mid x_i). \tag{9.7}$$

这就是通常的 *Markov* 条件：$X_{i+1},\dots,X_N$ 仅通过 X_i 依赖过去。请讨论 r 阶链的全局 *Markov* 性质。⋆

译注： 所列 A,B 的 r 应对应分离位置 i；式 (9.7) 左侧重复包含已给定的 x_i，应理解为其他变量的条件分布。

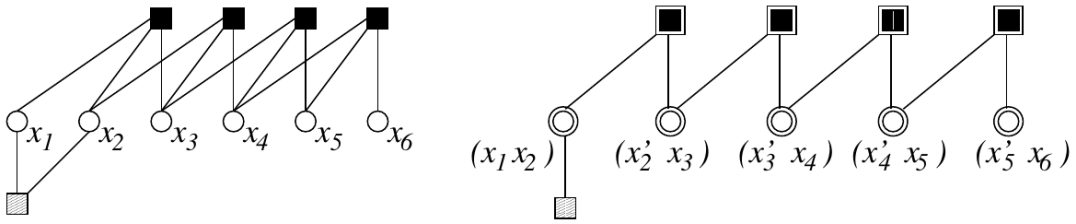


图 9.5: 左：长度 $N=6$、记忆范围 $r=2$ 的 Markov 链因子图。右：引入辅助变量后，同一分布写成一阶链。取自 Part C PDF 第 6 页（原 174）。

例 9.5. 考虑块长 $N=7$ 的码，码本定义为

$$\begin{aligned}\mathcal{C}=\{(x_1,x_2,x_3,x_4)\in\{0,1\}^4 : {}& x_1\oplus x_3\oplus x_5\oplus x_7=0,\\ & x_2\oplus x_3\oplus x_6\oplus x_7=0,\\ & x_4\oplus x_5\oplus x_6\oplus x_7=0\}.\end{aligned} \tag{9.8}$$

令 P_0 为码字上的均匀分布；如第 六章所述，编码按该分布产生码字是合理假设。于是

$$\begin{aligned}P_0(x)=\frac{1}{Z_0}&\mathbb{I}(x_1\oplus x_3\oplus x_5\oplus x_7=0)\mathbb{I}(x_2\oplus x_3\oplus x_6\oplus x_7=0)\\ &\times\mathbb{I}(x_4\oplus x_5\oplus x_6\oplus x_7=0),\end{aligned} \tag{9.9}$$

其中 $Z_0=16$。分布可分解，对应图 *9.6*。若经二元无记忆信道发送码字，收到 $(y_1,\dots,y_7)$，考虑给定输出的发送消息条件分布十分有用。请证明因子图为图 *9.6* 右图。⋆

译注： 原式 (9.8) 将 7 位码本写为 4 元组及 $\{0,1\}^4$，却使用 x_5,x_6,x_7；保留原误，正确环境应为 $\{0,1\}^7$。三个独立校验下确有 16 个码字，不能把原维数错误当作码的定义。

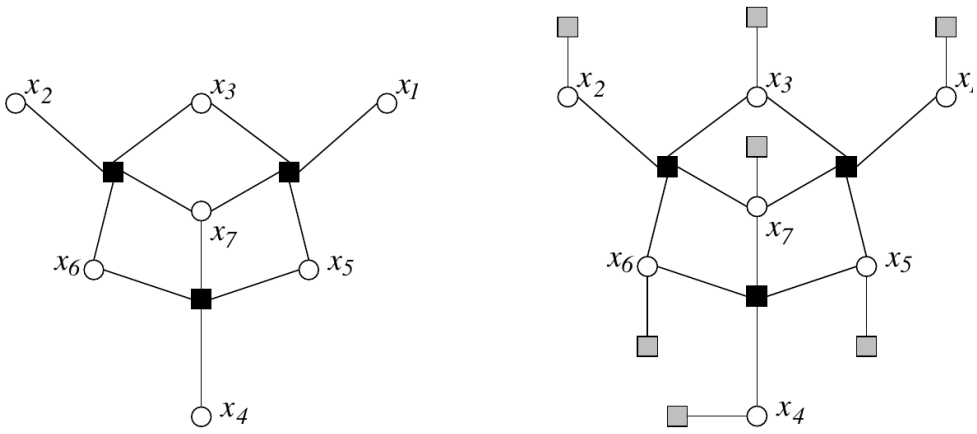


图 9.6: 左：式 (9.8) 所述码上均匀分布的因子图。右：给定信道输出的发送消息条件分布，灰色函数节点编码输出的信息。取自 Part C PDF 第 7 页（原 175）。

例 9.6. 第 *2.6* 节介绍 *Edwards–Anderson* 自旋玻璃，能量 $E(\sigma) = -\sum_{(ij)} J_{ij}\sigma_i\sigma_j - B\sum_i \sigma_i$。*Boltzmann* 分布可写成

$$p_\beta(\sigma) = \frac{1}{Z}\prod_{(ij)} e^{\beta J_{ij}\sigma_i\sigma_j}\prod_i e^{\beta B\sigma_i}, \tag{9.10}$$

其中 $i \in [L]^d$ 遍历边长 L 的 d 维立方晶格，(ij) 遍历最近邻对。图 *9.7* 的两类函数节点分别对应成对能量项 $-J_{ij}\sigma_i\sigma_j$（连接两个相邻变量）和场项 $-B\sigma_i$（连接一个变量）。

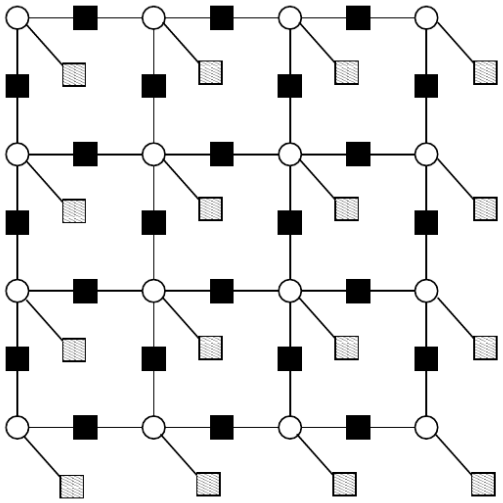


图 9.7: $d = 2, L = 4$ 的 Edwards–Anderson 模型因子图。实心方块为成对相互作用，阴影方块为场项。取自 Part C PDF 第 7 页（原 175）。

例 9.7. 可满足性是第 三章引入的判定问题：给定 N 个布尔变量 $x_i \in \{\mathrm{T}, \mathrm{F}\}$ 和 M 个逻辑子句，寻找同时满足所有子句的真值赋值。各子句的逻辑与称为公式。例如 $N = 7$ 时，

$$(x_1 \vee x_2 \vee \overline{x}_4) \wedge (x_2 \vee x_3 \vee x_5) \wedge (\overline{x}_4 \vee \overline{x}_5) \wedge (x_5 \vee \overline{x}_7 \vee \overline{x}_6). \tag{9.11}$$

若存在满足赋值，自然考虑其上的均匀分布 $P_{\rm sat}$，可以写为因子分解。例如

$$P_{\rm sat}(x_1,\dots,x_7)=\frac{1}{Z_{\rm sat}}\mathbb{I}(x_1\vee x_2\vee \overline{x}_4)\mathbb{I}(x_2\vee x_3\vee x_5)\\ \times\mathbb{I}(\overline{x}_4\vee\overline{x}_5)\mathbb{I}(x_5\vee\overline{x}_7\vee\overline{x}_6),\tag{9.12}$$

$Z_{\rm sat}$ 是满足式 (9.11) 的不同赋值数。请画出相应因子图。⋆

译注：否定号按可见 PDF 保留；原式 (9.12) 在第二因子后多一个右括号，仅配平排版。若不可满足，则 $Z_{\rm sat}=0$，均匀满足分布不存在。

习题 9.1. 考虑已见过的图 G 的 q 着色问题。构造因子图并写出相容函数。提示：最简单表示的函数节点数等于 G 的边数，各函数节点度为 2。

9.2 因子图系综：定义

我们一般关心式 (9.2) 的概率分布系综，下面介绍几类有用的因子图系综。所有函数节点度为 2 时，因子图对应普通图，即 Erdős 和 Rényi 最先研究的随机图系综。任意因子图通常只是简单推广：可将变量看作顶点、函数看作超边，得到超图；也可将两类节点都看作顶点，得到二部图。

对整数 $k\ge 1$，有 M 个函数节点、N 个变量节点的随机 k 因子图记为 $\mathbb{G}_N(k,M)$。对每个 $a\in\{1,\dots,M\}$，从 $[N]$ 的 $\binom{N}{k}$ 个 k 元组中均匀随机选取 ∂a。

有时需采用变体，例如不允许不同函数节点有相同邻域，即 $a\neq b$ 时 $\partial a\neq\partial b$。可用 $\mathbb{G}_N(k,\alpha)$ 系综：对每个 k 元组，独立地以概率 $\alpha/\binom{N}{k}$ 加入一个函数节点，连接该元组的所有变量。函数节点总数 M 随机，平均值 $M_{\rm av}=\alpha N$。**译注：**原定义的概率照录，但按此概率应有 $\mathbb{E}M=\alpha$，与下文 αN 不符。保持下文有限密度约定，应为 $\alpha N/\binom{N}{k}$，并要求它不超过 1。$\mathbb{G}_N(k,M)$ 的各函数邻域是独立有放回抽取，元组内部则为互异变量的无序子集；允许重复超边。$k=2$ 时对应的普通图因此可能有重边。

此后多考虑大图 $N\to\infty$、有限函数节点密度。对固定 M 系综，$M\to\infty$ 且 M/N 固定；对固定 α 系综，则保持 α 不变。下面习题提示，若干性质在此极限下不区分这两个系综。

习题 9.2. 在 $\mathbb{G}_N(k,M)$ 中，任意两个函数节点邻域都不同的概率 $p_{\rm dist}$ 是多少？证明固定 $M/N=\alpha,k$ 取大图极限时

$$p_{\rm dist}=\begin{cases}\Theta(e^{-\alpha^2N/2}), & k=1,\\ e^{-\alpha^2}[1+\Theta(N^{-1})], & k=2,\\ 1+\Theta(N^{-k+2}), & k\ge 3.\end{cases}\tag{9.13}$$

译注：精确概率为 $\prod_{j=0}^{M-1}(1-j/\binom{N}{k})$，$M>\binom{N}{k}$ 时为 0。$k=1$、固定 $0<\alpha<1$ 时 $N^{-1}\log p_{\rm dist}\to-\alpha-(1-\alpha)\log(1-\alpha)$，并不等于 $-\alpha^2/2$；后者只是小 α 展开的首项。$k\ge 3$ 的修正实际为负，原式的 $+\Theta$ 须按带符号误差理解，不能让概率超过 1。

习题 9.3. 考虑大图极限的 $\mathbb{G}_N(k,\alpha)$。证明 M 偏离均值 αN 一个广延量的概率指数小，即存在 $A>0$，对任意 $\varepsilon>0$，

$$\mathbb{P}[|M-M_{\mathrm{av}}|>N\varepsilon]\le e^{-AN\varepsilon^2}. \tag{9.14}$$

再证明：给定函数节点数为 M 的 $\mathbb{G}_N(k,\alpha)$，与给定所有函数邻域不同的 $\mathbb{G}_N(k,M)$ 分布相同。

译注： 本题须先采用与均值 αN 相容的加边概率。固定广延偏差可有 Chernoff 指数界，但对任意大小 ε 统一的纯二次指数常数不能无条件成立；需给定偏差范围或使用完整率函数。条件系综对应还要一致处理函数节点标号。

因子图一个重要的局部性质是度分布：Λ_i、P_i 分别为度为 i 的变量、函数节点比例。两者非负且归一化，只在有限多个度数上非零，原文写 Λ 最大为 N、P 最大为 M。将 (Λ,P) 称为图的度分布对，生成函数为

$$\Lambda(x)=\sum_{n\ge0}\Lambda_n x^n, \qquad\qquad P(x)=\sum_{n\ge0}P_n x^n.$$

它们是非负系数多项式，平均度分别为 $\Lambda'(1)$、$P'(1)$。随机图的度分布也随机。例如 $\mathbb{G}_N(k,M)$ 的变量度分布依赖具体图，而函数度分布 $P_n=\mathbb{I}(n=k)$ 确定。

定义度约束因子图系综 $\mathbb{D}_N(\Lambda,P)$ 为所有具有给定度分布对的图上的均匀分布。函数节点数由 $MP'(1)=N\Lambda'(1)$ 确定；系综非空的必要条件是所有 $N\Lambda_n, MP_n$ 为整数。即使满足这些条件，高效构造这种图也不显然。此系综对稀疏图码十分重要，构造问题留到第 11 章。特别重要的随机正则图固定两类节点的度：(k,l) 正则图中变量度为 l、函数度为 k，即 $\Lambda(x)=x^l$、$P(x)=x^k$。**译注：** 一般二部简单图的变量度至多 M、函数度至多 N，原文的两个上界互换。整数及总度相等只是必要条件，仍需图可实现性；空边数等退化情形也须单独约定。

9.3 随机因子图：基本性质

本节及后续推导几项简单性质。为简明，只研究 $k\ge2$ 的 $\mathbb{G}_N(k,M)$，固定 $M/N=\alpha, k$ 取 $N\to\infty$。向度约束图的推广见第 9.5.1 节及后续第 11 章。

9.3.1 度分布

令 $\deg_i$ 为节点 i 的度，期望线性给出 $\mathbb{E}\Lambda_n=\mathbb{P}[\deg_i=n]$。均匀选取的 k 元组包含 i 的概率为 $p=k/N$，因此

$$\mathbb{P}[\deg_i=n]=\binom{M}{n}p^n(1-p)^{M-n}, \qquad\qquad p=\frac{k}{N}. \tag{9.15}$$

固定 n 取大图极限，

$$\lim_{N\to\infty}\mathbb{P}[\deg_i=n]=\lim_{N\to\infty}\mathbb{E}\Lambda_n=e^{-k\alpha}\frac{(k\alpha)^n}{n!}. \tag{9.16}$$

节点度渐近服从 Poisson 分布。

不同节点的度有多强的相关性？逐个加入函数节点时，对 $i \neq j$，每个新函数有四种可能：同时连接 i, j，概率 $p_2 = k(k-1)/[N(N-1)]$；只连接其中一个，各概率 $p_1 = k(N-k)/[N(N-1)]$；都不连接，概率 $p_0 = 1 - 2p_1 - p_2$。于是

$$\mathbb{P}[\deg_i = n, \deg_j = m] = \sum_{l=0}^{\min(n,m)} \binom{M}{n-l, m-l, l} p_2^l p_1^{n+m-2l} p_0^{M-n-m+l}, \tag{9.17}$$

l 为同时连接两者的函数数，多项式系数的记号见附录 A。固定 n, m 时，$l = 0$ 项主导：多项式系数为 $\Theta(N^{n+m-l})$，而 $p_0 = \Theta(1)$、$p_1 = \Theta(N^{-1})$、$p_2 = \Theta(N^{-2})$，故第 l 项为 $\Theta(N^{-l})$。简单计算得

$$\mathbb{P}[\deg_i = n, \deg_j = m] = \mathbb{P}[\deg_i = n]\mathbb{P}[\deg_j = m] + \Theta(N^{-1}). \tag{9.18}$$

度是渐近两两独立的 Poisson 变量，由此可证明度分布接近期望：

$$\begin{aligned} \mathbb{E}(\Lambda_n - \mathbb{E}\Lambda_n)^2 &= \frac{1}{N^2} \sum_{i,j=1}^{N} \{\mathbb{P}[\deg_i = n, \deg_j = n] \\ &\qquad - \mathbb{P}[\deg_i = n]\mathbb{P}[\deg_j = n]\} \\ &= \Theta(N^{-1}). \end{aligned} \tag{9.19}$$

Chebyshev 不等式给出，任意 $\delta > 0$，$\mathbb{P}[|\Lambda_n - \mathbb{E}\Lambda_n| \geq \delta \mathbb{E}\Lambda_n] = \Theta(N^{-1})$。**译注：** 式 (9.17) 的多项式系数隐含第四类计数 $M - n - m + l$。原文多处把误差写成 $+\Theta$；相关修正未必为正，退化参数下也未必有该阶下界。由方差与 Chebyshev 直接推出的是概率 $O(N^{-1})$ 上界，不能仅凭此推出所写 Θ 等价。

这种独立性本质上源于两个给定变量共享函数节点的概率为 $\Theta(N^{-1})$，推广到任意有限多个变量也一样。若先给定函数节点 a 的邻域 $i_1, \ldots, i_k$，删去 a 后的剩余图属于 $\mathbb{G}_N(k, M-1)$；这些邻点的剩余度渐近独立 Poisson，均值 $k\alpha$。形式化如下。

命题 9.8. *设 $i_1, \ldots, i_n$ 为互异变量节点，图 $G \in \mathbb{G}_N(k, M)$ 条件化于 m 个函数节点 $a_1, \ldots, a_m$ 的指定邻域。将它们删去后的度记为 $\deg_i'$。固定 $M/N = \alpha, k, n, m$，取 $N \to \infty$ 时，这些剩余度依分布收敛到均值 $k\alpha$ 的独立 Poisson 变量。*

研究局部性质时这一性质特别有用，提示 $\mathbb{G}_N(k, N\alpha)$ 局部类似于 $P(x) = x^k$、$\Lambda(x) = \exp[k\alpha(x-1)]$ 的度约束系综。[3]

上面固定常数度 n 讨论大 N。典型图中会否存在异常大的度？下一习题作答。

[3]译注：有限图度分布是有限支集且满足整数计数的；这里的 Poisson 生成函数是极限描述，不能逐字当成每个有限 N 精确可实现的度分布。

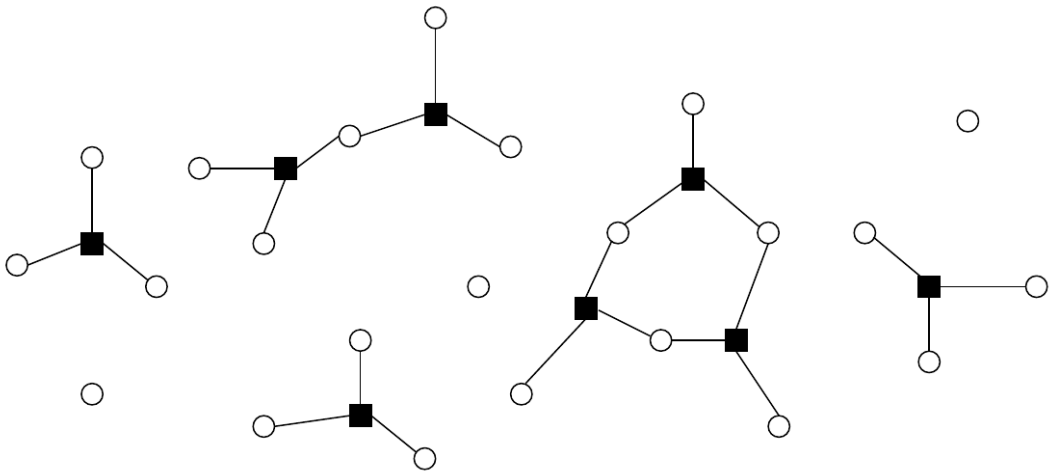


图 9.8: $k=3, N=23, M=8$ 的 $\mathbb{G}_N(k,M)$ 因子图。有 $Z_{\rm isol}=2$ 个孤立函数节点、$Z_{\rm coupl}=1$ 对孤立函数节点、$Z_{{\rm cycle},3}=1$ 个长为 3 的环，另 3 个变量度为 0。取自 Part C PDF 第 13 页 (原 181)。

习题 9.4. 研究最大变量度 $\Delta(G)$ 的典型性质。

1. 令 $\overline{n}_{\max}$ 为满足 $n>k\alpha$、$N\mathbb{P}[\deg_i=n]\le 1$ 的最小整数。证明大图时以趋于 *1* 的概率有 $\Delta(G)\le\overline{n}_{\max}$。提示：证明 $N\mathbb{P}[\deg_i=\overline{n}_{\max}+1]\to 0$；对度为 l 的节点数 Z_l 用一阶矩方法。

2. 证明

$$\frac{\overline{n}_{\max}}{k\alpha e}=\frac{z}{\log(z/\log z)}\left[1+\Theta\left(\frac{\log\log z}{(\log z)^2}\right)\right],\qquad z\equiv\frac{\log N}{k\alpha e}. \tag{9.20}$$

3. 令 $\underline{n}_{\max}$ 为满足 $N\mathbb{P}[\deg_i=n]\ge 1$ 的最大整数。证明以趋于 *1* 的概率有 $\Delta(G)\ge\underline{n}_{\max}$。提示：证明 $N\mathbb{P}[\deg_i=\underline{n}_{\max}-1]\to\infty$；对 Z_l 用二阶矩方法。

4. $\underline{n}_{\max}$ 的渐近行为如何？与 $\overline{n}_{\max}$ 比较。

译注：最大度并非有常数上界，主阶为 $\log N/\log\log N$。第三项的提示只直接支持 $\Delta\ge\underline{n}_{\max}-1$；在阈值期望不发散的子序列，原所要求的精确整数下界未获该论证保证，须核查差 1 及尾概率。此处没有执行题中所有数值或概率证明。

9.3.2 小子图

下一个简单问题是给定小子图出现的次数。这里只讨论几个例子。固定 k 个变量 $i_1,\dots,i_k$，它们被某函数节点同时连接的概率为 p。计算不被连接更容易：

$$1-p=\left[1-\binom{N}{k}^{-1}\right]^M. \tag{9.21}$$

方括号是单个函数未连接此元组的概率，独立的 M 个函数给出 M 次幂。大图时

$$p = \frac{\alpha k!}{N^{k-1}}[1 + \Theta(N^{-1})]. \tag{9.22}$$

这也确认：固定有限个变量中，任意两者共享函数的概率在大图时消失。

先数孤立函数节点：其相邻变量的度全部为 1。令数量为 Z_{isol}，则

$$\mathbb{E}Z_{\text{isol}} = M\left[\binom{N}{k}^{-1}\binom{N-k}{k}\right]^{M-1}. \tag{9.23}$$

M 来自任选函数 a。给定其邻域后，其余各函数不与这些变量相接的概率为方括号，必须对 $M-1$ 个函数都满足。大图时

$$\mathbb{E}Z_{\text{isol}} = N\alpha e^{-k^2\alpha}[1 + \Theta(N^{-1})]. \tag{9.24}$$

孤立函数有非零密度，密度在小 α 时因函数少而趋 0，大 α 时因难以孤立也趋 0。更精细分析表明，它紧密集中在均值附近，$O(N)$ 涨落概率指数消失。

也可不用精确式：均值等于 $M = N\alpha$ 乘以 k 个邻居在剩余图中度都为 0 的概率。命题 9.8 给出这些度近似独立 Poisson，所以概率近 $(e^{-k\alpha})^k = e^{-k^2\alpha}$。

对含多个函数的小结构，这种方法更方便。令 $Z_{\text{isol},2}$ 为恰共享一个变量、且与其余图隔离的函数对数，图 9.8 有 1 对。得到

$$\begin{aligned}\mathbb{E}Z_{\text{isol},2} = &\binom{N}{2k-1}\cdot\frac{k}{2}\binom{2k-1}{k}\cdot\left(\frac{\alpha k!}{N^{k-1}}\right)^2\\ &\times(e^{-k\alpha})^{2k-1}[1+\Theta(1/N)].\end{aligned} \tag{9.25}$$

各因子依次为：选取承载结构的 $2k-1$ 个变量；让两个函数恰共享一个变量的连接方式数；两个函数确实存在的概率；所有这些变量在剩余图中度为 0 的概率。改写为

$$\mathbb{E}Z_{\text{isol},2} = N\cdot\frac{1}{2}(k\alpha)^2 e^{-k(2k-1)\alpha}[1+\Theta(1/N)]. \tag{9.26}$$

进一步可证明它集中于均值，故孤立函数对也有有限密度。

一般小子图的最重要性质是数量随 N 的标度。N 仅进入选取承载变量及函数存在概率。若有 v 个变量、f 个函数，某指定类型的小结构数 $Z_{v,f}$ 满足

$$\mathbb{E}Z_{v,f} \sim N^{v-(k-1)f}. \tag{9.27}$$

将两类节点都视作顶点，因子图的连通子图、树、路径等与普通图同样定义。图 G 的分支 C 是连通且孤立的子图，即 C 与 $G\setminus C$ 间没有路径。

含 v 个变量、f 个度为 k 的函数的图是树，当且仅当 $v = (k-1)f+1$。*令 $Z_{\text{tree},v}$ 为随机图中含 v 个变量的孤立树数，由式 (9.27)，$\mathbb{E}Z_{\text{tree},v} \sim N$，故任意有限大小的树都有有限密度。不是树的子图满足 $v < (k-1)f+1$，数量不随 N 增长。换言之，几乎所有有限分支都是树。**译注：**树的计数判据及对非树的不等式要求子图连通，且这里只是函数节点度全为 k；不要求变量度也为 k。若 v 不满足可实现整数关系，该类型树计数为 0。固定结构尺度的结论不能未经一致控制推广到随 N 增长的分支。上式 $\sim$ 按原文描述幂次，不声称比例常数恒为 1。

习题 9.5. 图 *9.8* 最大分支含 *3* 个函数，令 $Z_{\mathrm{cycle},3}$ 为这种结构作为 $\mathbb{G}_N(k,M)$ 分支出现的次数，计算大图极限的期望。

习题 9.6. 若因子图只有一个闭合、不反向的简单路径 $\omega_0,\dots,\omega_\ell=\omega_0$，除循环平移外唯一，且 $0\le t\neq s<\ell$ 时 $\omega_t\neq\omega_s$，称为单环图。

1. 证明有 v 个变量、f 个度为 k 的函数的图为单环图，当且仅当 $v=(k-1)f$。

2. 令 $Z_{\mathrm{cycle},v}(N)$ 为含 v 个变量的单环分支数。用式 (9.27) 证明它在大图极限以高概率有限，即 $\lim_{n\to\infty}\lim_{N\to\infty}\mathbb{P}_{\mathbb{G}_N}[Z_{\mathrm{cycle},v}\ge n]=0$。

译注：第一项仍须连通；闭路径还应把正反两个遍历视为同一环。第二项精确表达的是计数依概率有界，而不是存在某个固定常数界使概率趋于 1。

9.4 随机因子图：巨型分支

上节说明，固定有限大小的分支大多是树，但大图不只包含有限树。保持 $\alpha=M/N$，取 $N,M\to\infty$，当 α 超过阈值，出现包含广延个变量节点、带有许多环的巨型分支。

9.4.1 有限树中的节点

希望估计有限树覆盖的节点比例，定义

$$x_{\mathrm{tr}}(\alpha,k)\equiv\lim_{s\to\infty}\lim_{N\to\infty}\frac{1}{N}\mathbb{E}N_{\mathrm{trees},s},\tag{9.28}$$

$N_{\mathrm{trees},s}$ 是大小不超过 s 的树中的变量节点数。令 $Z_{\mathrm{trees},v}$ 为大小 v 的树数，按上节方法

$$\begin{aligned}\mathbb{E}N_{\mathrm{trees},s}&=\sum_{v=0}^{s}v\,\mathbb{E}Z_{\mathrm{trees},v}\\&=\sum_{v=0}^{s}v\binom{N}{v}T_k(v)\left(\frac{\alpha k!}{N^{k-1}}\right)^{\frac{v-1}{k-1}}(e^{-k\alpha})^v[1+\Theta(1/N)]\\&=N(\alpha k!)^{-1/(k-1)}\sum_{v=0}^{s}\frac{T_k(v)}{(v-1)!}\left[(\alpha k!)^{1/(k-1)}e^{-k\alpha}\right]^v.\end{aligned}\tag{9.29}$$

$T_k(v)$ 是在 v 个互异变量和 $f=(v-1)/(k-1)$ 个度为 k 的函数上可构造的树数。第 9.4.3 节的枚举组合计算给出

$$T_k(v)=\frac{(v-1)!\,v^{f-1}}{[(k-1)!]^f f!}.\tag{9.30}$$

生成函数 $\widehat{T}_k(z)=\sum_{v=1}^{\infty}T_k(v)z^v/(v-1)!$ 满足自洽方程

$$\widehat{T}_k(z)=z\exp\left\{\frac{\widehat{T}_k(z)^{k-1}}{(k-1)!}\right\}.\tag{9.31}$$

原文称，任意 $z\ge0$ 都有两个非负解，*相关的是较小解，因为它在 $z=0$ 有正规的 Taylor 展开。据此可证明 x_{tr} 是

$$x_{\mathrm{tr}}=\exp(-k\alpha+k\alpha x_{\mathrm{tr}}^{k-1})\tag{9.32}$$

的最小正解。图 9.9 左图作图求解。$\alpha \le \alpha_p \equiv 1/[k(k-1)]$ 时，原文称唯一非负解是 $x_{\rm tr}=1$，几乎所有节点属于有限树；$\alpha > \alpha_p$ 时，相关解在 $(0,1)$，有限树比例严格小于 1。**译注：** 式 (9.29) 的 $v=0$ 在 $(v-1)!$ 中未定义，应从 $v=1$ 的可实现树大小求和；最后一行是大 N 主导式，不能将舍去误差的等号视为有限 N 精确等号。单变量树取 $T_k(1)=1$。式 (9.31) 有两个不同正解仅在 $0<z<z_c$，其中 $z_c=[(k-2)!]^{1/(k-1)}e^{-1/(k-1)}$；临界时合并，超过临界无非负实解。式 (9.32) 的 “唯一非负解” 应限制在概率区间 $[0,1]$，否则次临界时还可能有大于 1 的解。

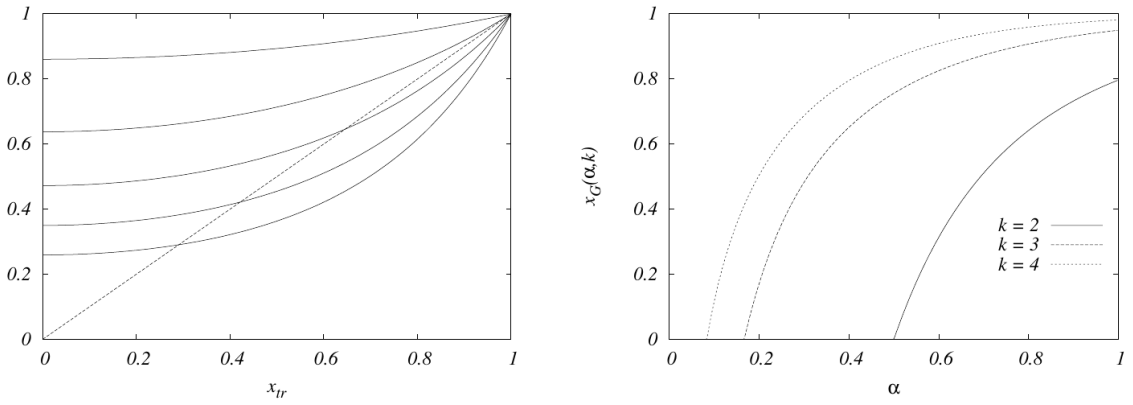


图 9.9: 左：有限树分支的变量比例方程 (9.32) 的图解，$k=3$，从上到下 $\alpha = 0.05, 0.15, 0.25, 0.35, 0.45$。右：巨型分支的典型大小。取自 Part C PDF 第 17 页（原 185）。

9.4.2 巨型分支的大小

这有些出人意料：$\alpha > \alpha_p$ 时，有正比例变量不属于任何有限树，而有限有环分支占据的节点比例又消失。余下约 $N(1-x_{\rm tr})$ 个节点在哪里？粗略说，它们属于唯一的非树连通分支，即巨型分支。基本结果如下。

定理 9.9. *令 X_1 为 $\mathbb{G}_N(k,M)$ 中最大连通分支的大小，$M=N[\alpha+o_N(1)]$，令 $x_G(\alpha,k)=1-x_{\rm tr}(\alpha,k)$，$x_{\rm tr}$ 为式 (9.32) 的最小解。对任意 $\varepsilon>0$，以高概率有*

$$|X_1 - N x_G(\alpha,k)| \le N\varepsilon. \tag{9.33}$$

巨型分支还有许多环。原文定义含 v 个顶点、f 个度为 k 的函数的图之环数为 $c=v-(k-1)f-1$，并称巨型分支 $c=\Theta(N)$，以高概率成立。**译注：** 这里 X_1、v 应按变量节点数理解。连通二部图的独立环数是边数减顶点数加 1，即 $kf-(v+f)+1=(k-1)f-v+1$，原定义符号相反。原定义及结论照录，不能将其解释成正的环数。线性数量的环是固定超临界参数的结论，不覆盖阈值和次临界。

习题 9.7. *说明不可能有超过一个大小 $\Theta(N)$ 的分支。可按如下路线：在 $M=N[\alpha+o_N(1)]$、固定正 s_1,s_2（原假设 $\alpha \ge s_1+s_2$）的图中，考虑出现大小 $\lfloor Ns_1\rfloor$、$\lfloor Ns_2\rfloor$ 两个分支的事件。逐个加入函数节点构造图，在只有 $M-\Delta M$ 个函数时必须满足什么条件？最后 ΔM 个函数可能发生什么？取 $\Delta M=\lfloor N^{\delta}\rfloor$、$0<\delta<1$。*

巨型分支的出现有时称为*完全图上的渗流*，是最简单的相变例子之一。下面给出正确预言其典型大小的启发式论证，也是后面腔方法最简单的例子。由期望线性 $\mathbb{E}X_1 = N x_G$，x_G 为给

定变量 i 属于巨型分支的概率。大图时 i 连接 $l(k-1)$ 个不同变量，l 是均值 $k\alpha$ 的 Poisson 变量。若任意一个邻居属于巨型分支，i 也属于它；假设各邻居独立以概率 x_G 属于巨型分支，则

$$x_G = \mathbb{E}_l[1-(1-x_G)^{l(k-1)}]. \tag{9.34}$$

取 Poisson 期望得

$$x_G = 1-\exp[-k\alpha + k\alpha(1-x_G)^{k-1}], \tag{9.35}$$

与式 (9.32) 在 $x_G = 1-x_{\rm tr}$ 下相同。

上述论证有几处缺陷，但只有一处严重：将若干随机邻居都不在巨型分支中的概率写成单点概率乘积。本例不难修补，后面会遇到不那么容易处理的同类推理。[4]

9.4.3 树的计数

本技术小节计算有 v 个变量、函数度全为 k 的树数 $T_k(v)$。先看 $k=2$：把每个函数替换成连接其邻居的一条边，因子图对应普通图。原则上可有重边，但树不会遇到此问题。因此 $T_2(v)$ 就是 v 个互异顶点上的普通树数。更方便的是数有根树 $T_2^*(v)$：有根图是图 G 加上一个特殊顶点 i_*，故 $T_2^*(v) = vT_2(v)$。

考虑 $v+1$ 个顶点的有根树，根度为 $1\le n\le v$。删去根及其边，将原相邻的 n 个顶点标为各自的根，留下大小 $v_1,\dots,v_n$ 的有根树，$v_1+\cdots+v_n = v$。因此对 $v\ge 1$，

$$T_2^*(v+1) = (v+1)\sum_{n=1}^{v}\frac{1}{n!}\sum_{\substack{v_1,\dots,v_n>0\\ v_1+\cdots+v_n=v}}\binom{v}{v_1,\dots,v_n}T_2^*(v_1)\cdots T_2^*(v_n). \tag{9.36}$$

加上 $T_2^*(1)=1$ 即可递推，见图 9.10。引入 $\widehat{T}(z)=\sum_{v>0}T_2^*(v)z^v/v!$，递推变成

$$\widehat{T}(z) = z\exp\{\widehat{T}(z)\}. \tag{9.37}$$

它与通常定义为 $W(z)e^{W(z)}=z$ 的 Lambert W 函数密切相关，实际 $\widehat{T}(z)=-W(-z)$。用下题的 Lagrange 反演作幂级数展开，得到 $T_2^*(v)=v^{v-1}$，因此 $T_2(v)=v^{v-2}$，即枚举组合学中著名的 *Cayley* 公式。

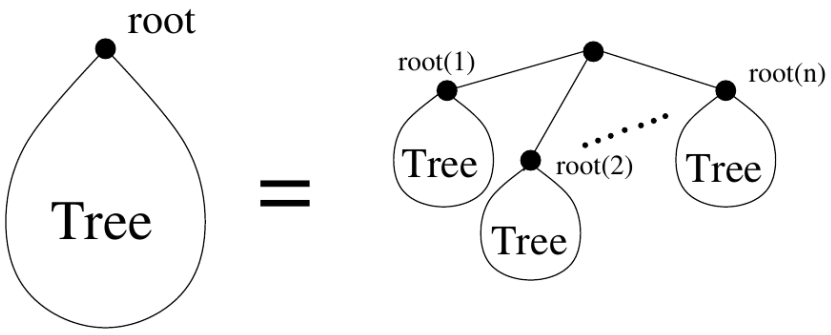


图 9.10: $v+1$ 个顶点的有根树 G 可拆成一个根和 n 棵有根树 $G_1,\dots,G_n$，它们各有 $v_1,\dots,v_n$ 个顶点。图内 root 表示根，Tree 表示树。取自 Part C PDF 第 19 页（原 187）。

[4]译注：有限 N 的成员概率与极限比例不必精确相同。腔论证应先删去根节点及相应已探查相互作用，在剩余图定义邻居成员事件，再取局部极限；原图中相邻节点的成员事件并不独立。唯一性表述是高概率的随机图结论，不是任意图不可能有两个大型分支。

习题 9.8. 设生成函数 $A(z)=\sum_{n>0}A_nz^n$ 满足 $z=f(A(z))$，f 解析，$f(0)=0$、$f'(0)=1$。用 *Cauchy* 公式 $A_n=\oint\frac{dz}{2\pi i}z^{-n-1}A(z)$ 证明

$$A_n=\mathrm{coeff}\{f'(x)(x/f(x))^{n+1};x^{n-1}\}. \tag{9.38}$$

用此 *Lagrange* 反演法求 $\widehat{T}$ 的幂级数，证明 *Cayley* 公式。

回到一般 k，类似推理得 $\widehat{T}_k(z)=\sum_{v>0}T_k^*(v)z^v/v!$ 满足*

$$\widehat{T}_k(z)=z\exp\left\{\frac{\widehat{T}_k(z)^{k-1}}{(k-1)!}\right\}, \tag{9.39}$$

从而

$$T_k^*(v)=\frac{v!\,v^{f-1}}{[(k-1)!]^f f!}, \tag{9.40}$$

其中 $v=(k-1)f+1$ 确定 f。[5]

9.5 随机图的局部树状结构

9.5.1 节点邻域

因子图变量间有自然距离：路径 $(\omega_0,\dots,\omega_\ell)$ 的长度定义为所含函数节点数，两变量距离为最短路径长度；不同分支约定距离 $+\infty$。变量 i 的半径 r 邻域 $B_{i,r}(F)$ 包含距离至多 r 的全部变量，以及只连接这些变量的全部函数节点。

典型节点的邻域是什么样？先考虑度约束图 $F\stackrel{\mathrm{d}}{=}\mathbb{D}_N(\Lambda,P)$，定义边视角度分布 $\lambda(x)=\Lambda'(x)/\Lambda'(1)$、$\rho(x)=P'(x)/P'(1)$：

$$\lambda(x)=\sum_{l=1}^{l_{\max}}\lambda_l x^{l-1},\qquad\qquad \rho(x)=\sum_{k=1}^{k_{\max}}\rho_k x^{k-1}. \tag{9.41}$$

λ_l、ρ_k 是随机一条边邻接度为 l 的变量或度为 k 的函数的概率。图中与这些变量、函数相接的边数分别为 $Nl\Lambda_l$、MkP_k，故

$$\lambda_l=\frac{l\Lambda_l}{\sum_{l'}l'\Lambda_{l'}},\qquad\qquad \rho_k=\frac{kP_k}{\sum_{k'}k'P_{k'}}. \tag{9.42}$$

逐步构造增长的邻域。给定 $B_{i,r}(F)$，令 $i_1,\dots,i_L$ 为距离恰为 r 的变量，$\deg'_{i_1},\dots,\deg'_{i_L}$ 为剩余图中的度。[6]类似命题 9.8 的论证表明，剩余度渐近独立同分布，$\deg'_{i_n}=l_n-1$，l_n 依 λ_{l_n} 分布。函数节点也一样，只需交换两类节点。

据此定义 r 代树系综 $\mathcal{T}_r(\Lambda,P)$：$r=0$ 时仅有一个第 0 代孤立节点；$r>0$ 时，先生成 $\mathcal{T}_{r-1}$ 的树。对第 $r-1$ 代每个变量 i，独立抽 $l_i\ge1$，分布为 λ_{l_i}，加入 l_i-1 个相邻函数。例外是 $r=1$ 时，按 Λ_{l_i} 抽取并加入 l_i 个函数。对每个新函数 a，独立按 ρ_k 抽 $k_a\ge1$，加入 k_a-1 个相邻变量，标为第 r 代。

[5]译注：这些公式把变量顶点标号，函数节点作为无标号超边计数；若将函数节点另行标号，须相应乘 $f!$，不能混用系综计数。单顶点树按 1 定义。

[6]原注：这里所谓剩余图，是 F 减去子图 $B_{i,r}(F)$。

固定函数度 k 的均匀随机图对应 $\mathcal{T}_r(e^{k\alpha(x-1)},x^k)$；容易验证剩余度是均值 $k\alpha$ 的 Poisson 分布，与命题 9.8 一致。⋆略微滥用记号，将此系综简记为 $\mathcal{T}_r(k,\alpha)$。

它们自然适合作为度约束系综和 $M\simeq N\alpha$ 的 $\mathbb{G}_N(k,M)$ 中半径 r 邻域的模型。精确结果如下。

定理 9.10. 设 F 为 $\mathbb{D}_N(\Lambda,P)$ 中随机因子图（相应地为 $\mathbb{G}_N(k,M)$），i 是均匀随机变量节点，r 为非负整数。固定 Λ,P（相应固定 α,k）取 $N\to\infty$，则 $B_{i,r}(F)$ 依分布收敛到 $\mathcal{T}_r(\Lambda,P)$（相应为 $\mathcal{T}_r(k,\alpha)$）。

换言之，因子图局部像该系综中的随机树。**译注：**边视角分布要求平均度非零，并沿图可实现的 N 序列取极限；给定多项式度分布对应有界支集。根按节点分布抽样时须允许 $l_i=0$，否则漏掉孤立变量；后代沿边抽样才要求 $l_i\geq 1$。“删去邻域”在探查过程应保留边界变量，删去已探查函数和内部节点，才可继续定义边界剩余度。定理固定 r，并不直接保证随 N 增大的半径仍然无环。

9.5.2 环

大图极限下 $\mathbb{G}_N(k,M)$ 局部收敛于树；第 9.3.2 节还说明固定小环只有 $\Theta(1)$ 个。自然想问：从给定节点出发多远时，环才起作用？更具体地，均匀随机变量 i 的最短经过自身的环，典型长度是多少？若 $k(k-1)\alpha<1$，多数节点属于小树，答案平凡；以下考虑 $k(k-1)\alpha>1$。

启发式估计如下。假设 $B_{i,r}$ 是树，每个函数在下一代有 $k-1$ 个变量，每个变量在下一代有均值 $k\alpha$ 的 Poisson 个函数。每代平均节点数乘 $k(k-1)\alpha$，总大小约 $[k(k-1)\alpha]^r$。当它与系统总节点数相比拟时出现环，即 $[k(k-1)\alpha]^r=\Theta(N)$，得 $r=\log N/\log[k(k-1)\alpha]$。这是粗糙但稳健的论证，把 N 换成 $N^{1\pm\varepsilon}$ 也只影响前因子。原文称结果正确，并可推广到度约束系综：

命题 9.11. 设 F 为 $\mathbb{D}_N(\Lambda,P)$ 中随机图（相应为 $\mathbb{G}_N(k,M)$），i 为均匀选取的随机变量，ℓ_i 为经过 i 的最短环长度。假设 $c=\lambda'(1)\rho'(1)>1$（相应为 $c=k(k-1)\alpha>1$），则以高概率

$$\ell_i=\frac{\log N}{\log c}[1+o(1)]. \tag{9.43}$$

译注：此命题按原文保留，但缺少根节点处于环上等条件，不能据现有假设成立。例如有限 $k\alpha$ 时，均匀节点孤立的概率趋于 $e^{-k\alpha}>0$，其 $\ell_i=\infty$，已排除无条件的“以高概率”有限公式；巨型分支中也有不在环上的悬挂树。邻域首次有环、某环经过根、以及根到环的距离是不同对象，不能直接互换。初步生日碰撞出现在邻域大小约 $\sqrt{N}$，也不能用“达到 N”直接证明最短根环公式。

证明参见文献；下题给出稍精确但仍为启发式的论证。

习题 9.9. 设树邻域 $B_{i,r}$ 含 n 个内部变量（距离小于 r）、n_l 个边界变量（距离等于 r）、m 个函数。令 F_r 为 F 减去该邻域的剩余图，原文称显然 $F_r\overset{\mathrm{d}}{=}\mathbb{G}_{N-n}(k,M-m)$。证明 F_r 中有函数连接两个边界变量的概率为

$$p_r=1-[(1-q)^k+k(1-q)^{k-1}q]^{M-m},\qquad q\equiv\frac{n_l}{N-n}. \tag{9.44}$$

先将 n_l, n, m 替换为树系综中的期望，记估计为 $\overline{p}_r$。假设 $r = \rho \log N / \log[k(k-1)\alpha]$，证明

$$\overline{p}_r = 1 - \exp\left\{-\frac{1}{2}k(k-1)\alpha N^{2\rho-1}\right\}[1 + O(N^{-2+3\rho})]. \tag{9.45}$$

$\rho > 1/2$ 时，这说明在没有经过 i、长不超过 $2r$ 的环这一假设下，高概率出现长为 $2r+1$ 的环；$\rho < 1/2$ 时则没有长至多 $2r+1$ 的根环。由此提示最短根环长度约为 $\log N / \log[k(k-1)\alpha]$。

译注： 本题仍须保留边界变量。固定 N 的 k 元组是不放回的，单个函数至多连接一个边界点的精确概率是 $[\binom{N-n-n_l}{k} + n_l\binom{N-n-n_l}{k-1}]/\binom{N-n}{k}$，原式二项表达只为近似，不能视为精确等号。用均值替换分支过程的随机大小也忽略灭绝及涨落；两个边界点的共同祖先未必是根，因此一次碰撞未必形成经过根的环。误差趋 0 还需相应限制 ρ，原结论不能代替缺条件的命题证明。

注释

因子图的良好入门是 Kschischang、Frey 和 Loeliger（2001），亦见 Aji 和 McEliece（2000）。它与图模型（Jordan，1998）、Bayes 网络（Pearl，1988）、编码中的 Tanner 图（Tanner，1981）相关。另一种表示是 Forney（2001）讨论的“正规实现”。

Hammersley–Clifford 定理起初受物理问题的概率建模推动，其证明可追溯到 1971 年。Clifford（1990）给出证明、详细引用及历史评论。

随机图理论由 Erdős 和 Rényi（1960）开创，巨型分支出现是他们的经典结果。标准教材 Bollobás（2001）、Janson、Łuczak 和 Ruciński（2000）详细研究相变。Bender 和 Canfield（1978）研究度约束图，Bollobás（1980）引入方便的“配置模型”，使 Molloy 和 Reed（1995）得以确定相变位置。Wormald（1999）综述度约束系综，包括短环性质。[7]

超图的一般背景见 Duchet（1995）。Schmidt-Pruzan 和 Shamir（1985）讨论固定超边大小 k 的巨型分支阈值，即这里的 $\mathbb{G}_N(k, M)$；Karónski 和 Łuczak（2002）及所引文献分析阈值附近。Darling 和 Norris（2005）以及编码理论的码系综中研究了不同超边大小的系综。度分布与度约束系综的定义、记号沿用编码文献（Luby、Mitzenmacher、Shokrollahi、Spielman 和 Stemann，1997；Richardson 和 Urbanke，2001a）。

随机图及更复杂随机对象，特别是随机标号图的局部结构，属于*局部弱收敛*理论（Aldous 和 Steele，2003）。第 9.5.1 节结果可在这一框架表述，原文此处参考为“???”。[8]

[7]译注：原文作 configuration mode，依语境译为配置模型。

[8]译注：保留原稿未完成引用，可唯一匹配的作者—年份条目已连接至 Part F；历史“最近”等仅按草稿年代理解。

第十章　可满足性

由第 三章的 Cook 定理，可满足性居于计算复杂性理论的核心，因而得到大量研究。本章不全面介绍这一广阔主题，而选取若干研究方向，特别关注随机可满足性实例系综的定义与分析。研究随机实例有多种动机。检验、改进算法时，希望自动生成 “困难” 实例；适当 “调节” 的系综可实现这一点。系综分析还揭示丰富结构，促成与其他学科的联系。后面还会用受统计物理启发的方法重访此问题，原稿此处章号为 “??”。

第 10.1 节回顾定义与术语。求解判定问题的一种基本策略，是穷尽探索变量全部赋值构成的树，第 10.2 节介绍其简单实现。第 10.3 节定义随机实例系综。问题难度依赖最大子句长度：长度 2 可在多项式时间判定，第 10.4 节讨论此情形。最后，第 10.5 节讨论 $K \geq 3$ 的随机 K-SAT 随子句密度变化的相变，并推导阈值的若干严格界。[1]

10.1　可满足性问题

10.1.1　SAT 与 UNSAT 公式

一个实例由 N 个布尔变量和 M 个子句约束给出。子句是若干变量或其否定的逻辑或。采用 $x_i \in \{0,1\}$，1 表示真、0 表示假，否定为 $\overline{x}_i \equiv 1 - x_i$。变量或其否定称为文字，记为 z_i，即 z_i 可为 x_i 或 $\overline{x}_i$。包含 K_a 个变量的子句 a，恰排除这些变量 2^{K_a} 种赋值中的一种。例如 $x_2 \vee \overline{x}_{12} \vee x_{37} \vee \overline{x}_{41}$ 仅在 $x_2 = 0, x_{12} = 1, x_{37} = 0, x_{41} = 1$ 时不满足；不满足的子句称被违反。

令 $\partial a = \{i_1^a, \ldots, i_{K_a}^a\} \subseteq [N]$ 为子句中的变量指标，$K_a = |\partial a|$。写 $C_a = z_{i_1^a} \vee \cdots \vee z_{i_{K_a}^a}$，整个实例为合取范式（CNF）

$$F = C_1 \wedge C_2 \wedge \cdots \wedge C_M. \tag{10.1}$$

如例 9.7 所见，示性函数 $\mathbb{I}(x \text{ 满足} F)$ 有自然的因子图表示。[2]更方便的表示区分两类边：x_i 出现时连实线，$\overline{x}_i$ 出现时连虚线，便得到 CNF 与图的一一对应，见图 10.1。[3]

---

[1]译注：本章关于阈值猜想、已有证明、最佳算法和历史知识状态的表述依所选作者草稿保留，不作为当前进展综述；原未定章号不猜测补写。

[2]原注：可能不存在满足赋值，此时示性函数无法归一化为概率测度，但仍可用因子图刻画其局部结构。

[3]译注：“恰排除一种” 假设子句涉及互异变量且无互补文字对；有重复、重言式子句时须先化简。图的一一对应也按变量、子句带标号且忽略子句及文字书写次序理解。

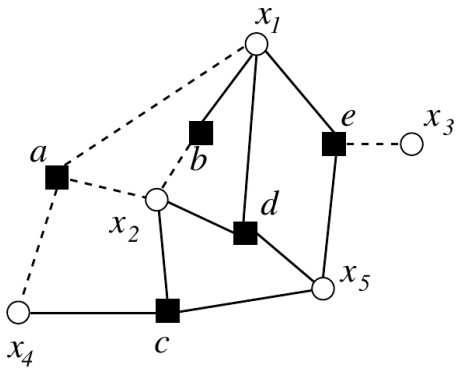


图 10.1: 公式 $(\overline{x}_1 \vee \overline{x}_2 \vee \overline{x}_4) \wedge (x_1 \vee \overline{x}_2) \wedge (x_2 \vee x_4 \vee x_5) \wedge (x_1 \vee x_2 \vee \overline{x}_5) \wedge (x_1 \vee \overline{x}_3 \vee x_5)$ 的因子图。取自 Part C PDF 第 26 页（原 194）。

判定问题问：2^N 个赋值中是否有使 F 为真的一个？求解算法应回答“是”并给出一个满足赋值，称公式为 SAT；否则回答“否”，称为 UNSAT。要求所有子句长度均为 K 的限制问题称为 K 可满足性（K-SAT）。对应优化问题要求找到违反子句数最少的赋值，称为 *MAX-SAT*。

习题 10.1. *考虑*

$$F_1 = (x_1 \vee \overline{x}_2) \wedge (x_2 \vee \overline{x}_3) \wedge (\overline{x}_2 \vee x_4) \wedge (x_4 \vee \overline{x}_1) \wedge (\overline{x}_3 \vee \overline{x}_4) \wedge (\overline{x}_2 \vee x_3).$$

证明它可满足，并给出满足赋值。提示：先取 $x_1 = 1$，子句 $x_4 \vee \overline{x}_1$ 变为单位子句 x_4，固定 $x_4 = 1$；继续“单位子句传播”，直到得到满足赋值或矛盾。

习题 10.2. *考虑 2-SAT 公式*

$$F_2 = (x_1 \vee \overline{x}_2) \wedge (x_2 \vee \overline{x}_3) \wedge (\overline{x}_2 \vee x_4) \wedge (x_4 \vee \overline{x}_1) \wedge (\overline{x}_3 \vee \overline{x}_4) \wedge (\overline{x}_2 \vee \overline{x}_3).$$

用前题方法证明该公式为 UNSAT。

译注：本题按可见 PDF 的否定号及原结论照录，但原结论不成立。全零赋值已满足 F_2；对 16 种赋值有限穷举，F_1 有 3 个、F_2 有 4 个满足赋值。例如 $(1,0,0,1)$ 也同时满足两者。没有据原题意擅自改动文字的正负号。

习题 10.3. *考虑 3-SAT 公式*

$$\begin{aligned} F_3 = {} & (x_1 \vee x_2 \vee \overline{x}_3) \wedge (x_1 \vee x_3 \vee \overline{x}_4) \wedge (x_2 \vee x_3 \vee x_4) \\ & \wedge (\overline{x}_1 \vee x_2 \vee \overline{x}_4) \wedge (x_1 \vee \overline{x}_2 \vee x_4) \wedge (\overline{x}_1 \vee \overline{x}_2 \vee x_4) \\ & \wedge (\overline{x}_2 \vee \overline{x}_3 \vee \overline{x}_4) \wedge (x_2 \vee \overline{x}_3 \vee x_4) \wedge (\overline{x}_1 \vee x_3 \vee \overline{x}_4). \end{aligned}$$

证明不可满足。提示：用第 10.2.2 节的决策树推广前面方法，或列出 16 个赋值，逐一划去每个子句排除的赋值。

译注：本题 9 个子句的否定号已逐项核对，并有限穷举确认没有满足赋值。

可满足性是首个被证明 NP 完全的问题。要求每个 $K_a \le 2$ 则可多项式求解，放宽到 $K_a \le K$、$K \ge 3$ 后为 NP 完全。例如 3-SAT 为 NP 完全，2-SAT 为多项式问题。直观上 MAX-SAT“至少一样难”，因为最少违反数为 0 当且仅当原式 SAT；不那么显然的是，它可能 “难得多”：MAX-2-SAT 是 NP 困难，判定 2-SAT 却在 P 中。[4]

本书不讨论应用，但须记住它关联众多实际重要问题，在数理逻辑、计算理论、人工智能中有直接意义；应用从集成电路的建模、布局、布线和测试，到计算机体系结构中的编译优化、调度与任务划分，再到图形学和图像处理。

10.2 算法

10.2.1 简单情形：2-SAT

做过习题 10.1、10.2 的读者，已能感到 2-SAT 容易。主要工具是*单位子句传播*（UCP）。对二元子句 $C = z_1 \vee z_2$，固定 z_1 后：

- $z_1 = 1$ 时子句满足，从公式删除；
- $z_1 = 0$ 时化为单位子句 z_2，强制 $z_2 = 1$。

从某个变量 $x_i = 0$ 开始，化简所有含 x_i 或 $\overline{x}_i$ 的子句，再递归固定单位子句的文字。过程因两种原因停止：没有单位子句，或同时出现 z_j 与 $\overline{z}_j$ 两个单位子句。

第一种情况得到未违反任何子句的部分满足赋值。稍后证明：它可扩展为完整满足赋值，当且仅当原公式 SAT。因此可再选未固定变量继续。第二种情况无法扩展，便将起始选择改为 $x_i = 1$。若这次无矛盾停止，已固定变量以后不必重考虑；若两种取值都导致矛盾，显然原式必为 UNSAT。⋆

该算法很高效。用固定变量操作数衡量，每个变量至多考虑两次，最多 $2N$ 次。正确性只需证明：原式 SAT 且 UCP 无矛盾停止时，部分赋值可以扩展。此时剩余变量集合 R 上的公式只含原公式中完全涉及 R 的子句；任何原满足赋值限制到 R 都满足它，从而扩展当前部分赋值。[5]

习题 10.4. *编程实现上述 2-SAT 算法。*

---

[4]译注：这里的难度比较依复杂性类及已知归约，不证明 P 与 NP 不同。

[5]译注：复杂度 $2N$ 只统计赋值次数，实际运行时间还要包括子句扫描、传播及恢复；可以用蕴含图的强连通分支算法在输入长度的线性时间判定 2-SAT。初始单位子句或空子句应先处理，且反转起始决策前须撤销其传播赋值。原习题 10.2 的错误不影响这里的一般算法。

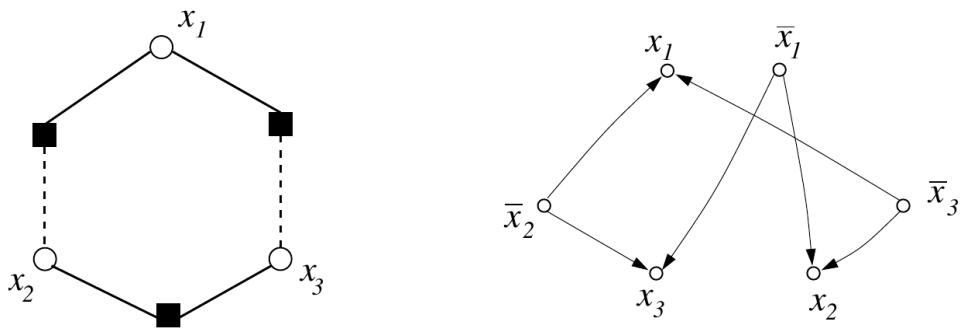


图 10.2: 2-SAT 公式 $F=(x_1\vee\overline{x}_2)\wedge(x_1\vee\overline{x}_3)\wedge(x_2\vee x_3)$ 的因子图（左）及对应有向图 $D(F)$（右）。取自 Part C PDF 第 29 页（原 197）。

习题 10.5. 把公式 F 关联到有向图 $D(F)$，可直观理解 *UCP* 为何适合 *2-SAT*。每个文字一个顶点，共 $2N$ 个，如 x_1、$\overline{x}_1$ 分别对应顶点。若有子句 $\overline{x}_1\vee x_2$，则 $x_1=1$ 蕴含 $x_2=1$，$x_2=0$ 蕴含 $x_1=0$，画边 $x_1\to x_2$、$\overline{x}_2\to\overline{x}_1$。证明 F 为 *UNSAT* 当且仅当存在某 i，图中同时有 $x_i\to\overline{x}_i$ 与 $\overline{x}_i\to x_i$ 的有向路径。提示：将 *UCP* 改述为有向图中寻找这两条路径的算法。勿将此图与因子图混淆。

这个过程除了判定最少违反数是否为 0，并未提供有效求解 MAX-2-SAT 的线索，后者仍是 NP 困难。

10.2.2 一般完备算法

允许无界多个长度至少 3 的子句后，问题成为 NP 完全。习题 10.3 展示 UCP 策略为何失效：固定 3 子句中的一个变量，可留下原来没有的 2 子句。因此即使 UCP 无矛盾停止，部分赋值也未必可扩展，即使原式 SAT。发现矛盾后，可能须反转此前任一决策；2-SAT 则只需改变最近选择。最方便的描述是决策树：每逢矛盾，回溯到最近一个尚未探索完两种可能的分支。

最常用的完备算法，即能找到满足赋值或证明不存在的算法，采用这一思路，称为 DPLL，取自 Davis、Putnam、Logemann、Loveland 的首字母。图 10.3 给出递归过程，原稿伪代码为：

DPLL 输入：CNF 公式 F；输出：满足赋值，或 “F 为 UNSAT”。

1. 初始化 $n=0$、$G(0)=F$。
2. 若 $G(n)$ 无子句，对其中仍出现的各变量返回 $x_i=0$，停止。
3. 若 G 含空子句，返回 “F 为 UNSAT”，停止。
4. 从尚未固定的变量选一个指标 i。
5. 固定 $x_i=1$，由 $G(n)$ 得 $G(n+1)$。
6. 令 $n\leftarrow n+1$，转第 2 步。
7. 令 $n\leftarrow n-1$。（未找到 $x_i=1$ 的满足赋值。）
8. 固定 $x_i=0$，由 $G(n)$ 得 $G(n+1)$。
9. 令 $n\leftarrow n+1$，转第 2 步。

译注： 此原伪代码缺失递归返回和回溯控制：第 6 步无条件跳转，第 7 步不可直接到达；分支失败也不能立即断言整个 F 不可满足。第 2 步还须连同已作的决策返回完整赋值。原代码保留，不能直接当作正确可运行的实现；正文所述 DPLL 需在两个分支都失败后向上返回失败，仅根处可判全式 UNSAT。

$G(n)$ 跟踪当前剩余公式，算法状态对应决策树节点，n 为深度。每次固定变量都化简子句：含正文字 x_i 的子句在 $x_i = 1$ 时删除，在 0 时删去该文字；负文字相反。

原代码未规定如何选下一个变量。DPLL 的不同变体在选择与分支顺序上不同。UCP 对应规则是：若 $G(n)$ 有长度 1 子句，必须从其中选变量。这时不发生真正分支，例如单位子句 x_i 强制 1，试 0 马上产生空子句。其他情形如何选分支变量是一门艺术，可导致性能差异。选出现于许多子句的变量通常有利，也可考虑将触发多少 UCP。通常以分支点数衡量性能，虽未统计实际操作，但对合理启发式，两者至多差输入规模的多项式因子，不影响主导指数行为。

DPLL 完整搜索后未返回满足赋值，则原式 UNSAT，探索树给出证明，称*不可满足证书*。其长度一般大于输入大小的多项式，与仅需给出一个赋值的 SAT 证书不同。[6]

习题 10.6. *归结与 DPLL。*

1. *若 F 含 $x_j \vee A$、$\overline{x}_j \vee B$，其中 A, B 是子句，证明它们蕴含关于 x_j 的归结子句 $A \vee B$。*

2. *不断向 F 加入归结子句构造归结证明。若产生空子句，证明原式必为 UNSAT。证书就是导出空子句的归结序列。*

3. *任何 DPLL 树都是归结证明。先用原公式在该分支上矛盾的子句对的归结，标记各 UNSAT 叶。如图 10.3 最左叶对应 $x_1 \vee x_2 \vee \overline{x}_3$ 与 $x_1 \vee x_2 \vee x_3$，在 x_3 上归结得 $x_1 \vee x_2$。证明每个分支点可标为两个子节点标签的归结；若公式 UNSAT，此过程在根部得到空子句。*

译注：一般叶可先以该分支实际被违反的原子句标记，再向上归结；如一侧标签不含分支文字，可直接传递相应子句，不必每个节点都机械要求恰一次双亲归结。

[6]译注：必须限定完整终止且正确回溯的搜索；超时或资源耗尽不是 UNSAT 证书。原文对证书长度的概括指这类搜索或特定证明系统的最坏情形，不是证明所有不可满足公式的所有证明必超多项式。

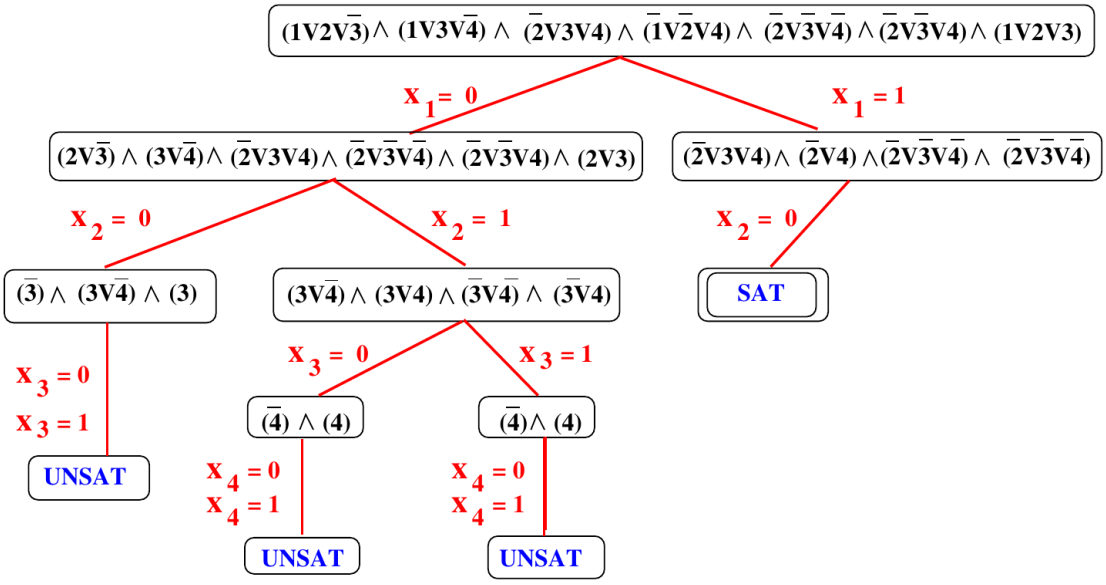


图 10.3: DPLL 算法示意。作用于公式 $(x_1 \vee x_2 \vee \overline{x}_3) \wedge (x_1 \vee x_3 \vee \overline{x}_4) \wedge (\overline{x}_2 \vee x_3 \vee x_4) \wedge (\overline{x}_1 \vee x_2 \vee x_4) \wedge (\overline{x}_2 \vee \overline{x}_3 \vee \overline{x}_4) \wedge (\overline{x}_2 \vee \overline{x}_3 \vee x_4) \wedge (x_1 \vee x_2 \vee x_3) \wedge (\overline{x}_1 \vee x_2 \vee \overline{x}_4)$。为可读性，将如 $\overline{x}_1 \vee x_2 \vee x_4$ 简记为 $(\overline{1}\,2\,4)$。先固定 $x_1 = 0$，原图注称含 x_1 的子句删除、含 $\overline{x}_1$ 的子句删去此文字；再固定下一个变量。每步有单位子句时优先选其中变量，即 UCP。发现同一变量被强制取 0 及 1 的矛盾时，回溯到最近未完成的分支试另一选择。本例先取 $x_1 = 0, x_2 = 0$，UCP 给出 $x_3 = 0$ 和 1 的矛盾，故反转 $x_2 = 1$ 继续。这里采用按原文所称 “子句指标” 固定顺序分支的朴素规则。取自 Part C PDF 第 32 页（原 200）。

译注： 图注在 $x_1 = 0$ 时所写的删除正、缩短负文字的规则反了，应交换；图内根的子句串与图注所列公式也未完全一致，均保留源图与原图注，不据此图单独认证一条搜索轨迹。最后的分支顺序应按变量指标理解，原称子句指标。

10.2.3 不完备搜索

证明 SAT 只需展示满足赋值，比证明 UNSAT 容易。因此可放宽目标，只寻找满足赋值，称为*不完备搜索*：找到解便返回，否则在无法找到或无法证明 UNSAT 时回答 “不知道”。

Schöning 的简单算法采用随机游走：

Walk(F) 输入：CNF 公式；输出：满足赋值，或 “不知道”。

1. 每个变量独立以各 1/2 概率取 0 或 1。
2. 重复 $3N$ 次以下操作：
   (a) 若当前赋值满足 F，返回并停止。
   (b) 均匀随机选一个未满足子句。
   (c) 从该子句均匀选一个变量 x_i。
   (d) 翻转它，即 0 变 1、1 变 0。

算法有如下性能保证。

命题 10.1. 令 $p(F)$ 为在公式 F 上执行该例程找到满足赋值的概率。若 F 为 SAT，则 $p(F) \geq p_N$，其中

$$p_N = \frac{2}{3}\left(\frac{K}{2(K-1)}\right)^N. \tag{10.2}$$

译注： 此界的语境须为长度至多 $K \geq 3$ 的子句；原输入只写一般 CNF，且未在命题列出 K 条件。特别不能将 $K = 2$ 代入并声称 $3N$ 次近无偏游走有常数成功概率。循环耗尽时还应返回“不知道”，最后一次翻转后是否再检查也须约定。

独立重复可提高成功率。若原式 SAT，运行 $20/p_N$ 次，未找到解的概率至多 $(1-p_N)^{20/p_N} \leq e^{-20}$。这当然不是不可满足性证明，但已十分接近。一般将错误概率压到固定 ε 所需时间主导指数为

$$\tau_N \doteq \left(\frac{2(K-1)}{K}\right)^N. \tag{10.3}$$

它相比约 2^N 的朴素穷举有指数改进。[7]

证明. 若 F 为 SAT，取一个满足赋值 x^*。令 x_t 为翻转 t 次后的赋值，d_t 为它与 x^* 的 Hamming 距离，初始

$$\mathbb{P}\{d_0 = d\} = \frac{1}{2^N}\binom{N}{d}. \tag{10.4}$$

每个子句至少有一个变量在 x^* 下满足它，恰标记其中一个。每次从违反子句选变量时，以 $1/K$ 概率选中标记，使距离减 1；其他翻转有时也减 1。引入辅助整数 $\widehat{d}_t$：选中标记则减 1，否则加 1，这是单次翻转的最大距离增量。取 $\widehat{d}_0 = d_0$，有 $d_t \leq \widehat{d}_t$。

原文接着说，可用 $\widehat{d}_t$ 在 $0 \leq t \leq 3N$ 达到 0 的概率“上界” Walk 找解的概率；并称该半直线偏置游走以概率 $1/K$“向右”、以 $1-1/K$ 也“向右”移动。达到原点的概率可估计为式 (10.2)，见下题。

习题 10.7. 分析偏置游走 $\widehat{d}_t$。

1. 证明从 d 起步、在时刻 t 到 0 的概率为

$$\mathbb{P}\{\widehat{d}_0 = d; \widehat{d}_t = 0\} = \frac{1}{2^N}\binom{N}{d}\frac{1}{K^t}\binom{t}{(t-d)/2}(K-1)^{(t-d)/2}, \tag{10.5}$$

   当 $t+d$ 为偶数成立，奇数时为 0。

2. 用 *Stirling* 公式求主导指数 $\mathbb{P}\{\widehat{d}_0 = d; \widehat{d}_t = 0\} \doteq e^{-N\Psi(\theta,\delta)}$，$\theta = t/N$、$\delta = d/N$。

3. 对 $\theta \in [0,3]$、$\delta \in [0,1]$ 极小化 Ψ，证明最小值为 $\Psi_* = \log[2(K-1)/K]$，并说明主导指数为 $p_N \doteq e^{-N\Psi_*}$。

□

[7] 译注：失败概率的界以原式 SAT 为假设，不是给定失败后公式 UNSAT 的后验概率；不能当作不可满足证书。重复次数需取整，时间式忽略多项式因子。

译注：这里“上界”应为下界：辅助距离达到 0 保证原过程已找到解；概率 $1/K$ 的步应向左。两处原文错误已显式照录提示，不改变所求下界方向。式 (10.5) 是未吸收整数游走的位置概率，非直接的首次到达分布；若在 0 吸收，须区分到达时刻。仅求主导指数也不足以证明命题的精确前因子 2/3，仍需到达时间控制。

此算法很嘈杂：虽“聚焦”违反子句，步子基本随机。相反策略是贪婪步，即翻转使满足子句数增加最多的变量。一个很有效的改进是混合：以概率 p 随机选违反子句并翻转其中随机变量，以概率 $1-p$ 贪婪翻转。适当优化 p 后表现不错，贪婪步引向“准解”，噪声则帮助逃出局部极小值。

10.3 随机K 可满足性系综

可满足性为 NP 完全，因而预期完备算法最坏情形耗费指数时间，但经验上许多公式容易求解。一个自然方向是用实例空间的概率测度区分容易和困难的系综。[8]

重要的一类是*随机 K-SAT*，仅含长为 K 的子句。系综记为 $\mathrm{SAT}_N(K,M)$，从 $\binom{N}{K}2^K$ 个可能子句均匀随机选 M 个。其因子图属于 $\mathbb{G}_N(K,M)$。关键参数是*子句密度* $\alpha = M/N$；固定密度取 $M,N\to\infty$ 为“热力学”极限，若干重要性质集中在典型值附近。

变体 $\mathrm{SAT}_N(K,\alpha)$ 独立地以概率 $\alpha N 2^{-K}/\binom{N}{K}$ 包含每个可能子句。原文称其因子图属于第 9.2 节 $\mathbb{G}_N(K,\alpha)$。许多性质在热力学极限不区分这些变体，类似不同因子图系综的等价。**译注：**固定 M 模型按独立有放回取子句理解。Bernoulli 变体中，同一变量元组的不同正负模式可同时出现，因而可有重复邻域；它与简单超边版 $\mathbb{G}_N(K,\alpha)$ 并非有限 N 精确同分布。第 9 章该系综定义的漏 N 问题也须区分；此处子句加入概率与均值 αN 相容，且须不超过 1。

10.3.1 数值实验

用 DPLL 可研究随机实例。图 10.4 给出 $K=2,3$ 时可满足概率 $P_N(K,\alpha)$。固定 K,N 时，它随 α 递减，小密度趋 1，大密度趋 0。随 N 增加，高到低的过渡越来越尖锐，提示有限阈值 $\alpha_c(K)$ 的相变：低于阈值以趋于 1 的概率 SAT，高于阈值则 UNSAT。

[8]译注：指数最坏时间是这里的预期，不是由 NP 完全性已证明的算法下界。

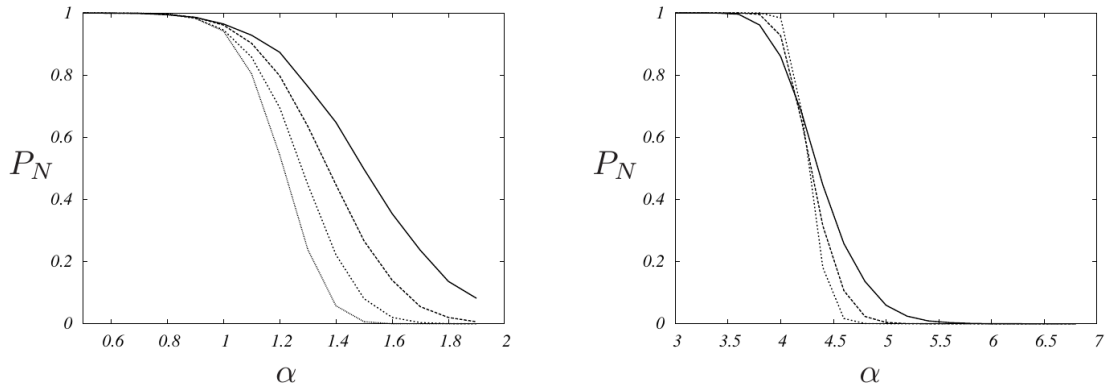


图 10.4: 随机 K-SAT 公式可满足的概率随子句密度的变化，左 $K=2$，右 $K=3$。用 DPLL 生成，每点平均 10^4 个随机公式。左图从右到左 $N=50,100,200,400$；右图实线 $N=50$、虚线 100、点线 200。N 越大，过渡越尖锐。取自 Part C PDF 第 36 页（原 204）。

$K \geq 3$ 的相变猜想备受关注，一项原因是计算工作量。图 10.5 给出求解随机 3-SAT 所需 DPLL 分支节点数。在相变区域，工作量随密度有峰，并随 N 迅速增大。细看有三个区域：低 α 易找到解，时间多项式增长；中等 α 的相变区典型地很难，时间指数增长；更大 α 几乎总不可满足，较容易但搜索树仍随 N 指数增长。因此最难随机 3-SAT 实例集中于假设的相变区域，对复杂性与统计物理都很有意义。[9]

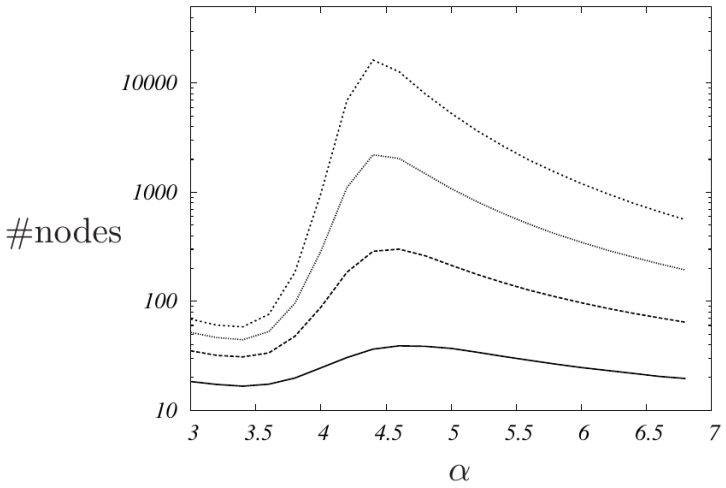


图 10.5: 本书 DPLL 求解随机 3-SAT 的计算工作量。原图注称纵轴为搜索树分支节点数的对数对 10^4 实例的平均，横轴为 α；从下到上 $N=50,100,150,200$。取自 Part C PDF 第 37 页（原 205）。

[9]译注：这些是所示规模、所选 DPLL 启发式的数值观察，不能从有限规模曲线认证所有算法的典型或最坏复杂度。

10.4 随机 2-SAT

2-SAT 不仅复杂性为多项式，随机情形也更易分析。重要原因是第 10.2.1 节算法，特别是习题 10.5 的文字有向图表示，可用随机有向图理论详细分析，并严格确立临界密度 $\alpha_c(2)=1$。

定理 10.2. 令 $P_N(2,\alpha)$ 为 $\mathrm{SAT}_N(2,M)$ 中公式可满足的概率，则

$$\lim_{N\to\infty} P_N(2,\alpha)=\begin{cases}1, & \alpha<1,\\ 0, & \alpha>1.\end{cases} \tag{10.6}$$

证明. 这里只证明 $\alpha<1$ 时高概率 SAT。原文称 $\alpha>1$ 的结果来自下面的定理 10.5。用习题 10.5 的有向图，将长为 s 的自行车定义为路径 $(u,w_1,\dots,w_s,v)$，其中 w_i 为 s 个互异变量上的文字，$u,v\in\{w_1,\dots,w_s,\overline{w}_1,\dots,\overline{w}_s\}$。若原式 UNSAT，有一个包含 $x_i,\overline{x}_i$ 的环，可从中构造自行车。于是

$$\begin{aligned}\mathbb{P}(F\text{ 为 UNSAT})&\le\mathbb{P}(D(F)\text{ 有自行车})\\ &\le\sum_{s=2}^{N}N^s2^s(2s)^2M^{s+1}\left(\frac{1}{4\binom{N}{2}}\right)^{s+1}.\end{aligned} \tag{10.7}$$

求和遍历大小 s；N^s 上界变量选取数，2^s 选择文字，$(2s)^2$ 选择 u,v，M^{s+1} 上界所用子句的选择，最后因子是各所需子句出现的概率。当 $M/(N-1)<1$，对级数直接求和可得大 N 时为 C/N，C 为常数。 □

译注： 定理 10.5 的朴素一阶矩界在 $K=2$ 为 $-\log 2/\log(3/4)\approx 2.409$，不能推出全部 $\alpha>1$ 的结果，原交叉引用有误。自行车计数需选取对应 $s+1$ 个互异子句的非退化结构；只允许任意端点的路径定义还会包含退化走法，不能未经排除就用独立子句概率。C/N 的统一估计要求固定 $\alpha<1$，不是令 $M/(N-1)$ 任意逼近 1 也保持同一常数。临界点不在此定理两分支结论内。

10.5 随机$K\ge 3$ SAT 的相变

10.5.1 可满足性阈值猜想

数值研究提示任意 $K\ge 2$ 都有 SAT 到 UNSAT 的相变，普遍相信如下猜想。

猜想 10.3. 任意 $K\ge 2$ 都存在阈值 $\alpha_c(K)$，使

$$\lim_{N\to\infty} P_N(K,\alpha)=\begin{cases}1, & \alpha<\alpha_c(K),\\ 0, & \alpha>\alpha_c(K).\end{cases} \tag{10.8}$$

$K=2$ 已证明；原稿写作时，较大 K 仍为开放问题，下面的定理提供支持。

定理 10.4 (Friedgut)**.** 令 $P_N(K,\alpha)$ 为 $\mathrm{SAT}_N(K,M)$ 的可满足概率，$K\ge 2$，则存在序列 $\alpha_c^{(N)}(K)$，对任意 $\varepsilon>0$，

$$\lim_{N\to\infty} P_N(K,\alpha)=\begin{cases}1, & \alpha<\alpha_c^{(N)}(K)-\varepsilon,\\ 0, & \alpha>\alpha_c^{(N)}(K)+\varepsilon.\end{cases} \tag{10.9}$$

即转变随 N 越来越尖锐，大 N 时窗口小于任意固定宽度。证明阈值猜想“只”缺序列 $\alpha_c^{(N)}(K)$ 收敛到某个 $\alpha_c(K)$。[10]

10.5.2 上界

大 N 时 $\alpha_c^{(N)}$ 的严格上界可用一阶矩方法得到。策略是找公式的非负整数函数 $U(F)$，满足

$$U(F) = \begin{cases} 0, & F \text{ 为 UNSAT}, \\ \geq 1, & \text{否则}, \end{cases} \tag{10.10}$$

则随机公式有

$$\mathbb{P}\{F \text{ 为 SAT}\} \leq \mathbb{E}U(F). \tag{10.11}$$

若 U 就是 SAT 示性函数则等号成立，但不能直接算其期望。应找容易计算、且在足够大 α 时均值趋 0 的 U。

最简单取满足赋值数 $U = Z(F)$，类似“零温”配分函数。任意赋值满足随机子句的概率同为 $1 - 2^{-K}$，独立的 M 个子句给出

$$\mathbb{E}Z(F) = 2^N(1-2^{-K})^M = \exp\{N[\log 2 + \alpha \log(1-2^{-K})]\}. \tag{10.12}$$

所以 $\alpha > \alpha_{\mathrm{UB},1}(K)$ 时均值指数小，其中

$$\alpha_{\mathrm{UB},1}(K) \equiv -\frac{\log 2}{\log(1-2^{-K})}. \tag{10.13}$$

定理 10.5. *若 $\alpha > \alpha_{\mathrm{UB},1}(K)$，则 $\lim_{N\to\infty}\mathbb{P}\{F \text{ 为 } SAT\} = 0$。因此任意 $\delta > 0$、足够大 N 时，$\alpha_c^{(N)}(K) < \alpha_{\mathrm{UB},1}(K) + \delta$。*

不应期待此界紧，因为 SAT 相的 $Z(F)$ 指数大，其涨落往往也随 N 指数增长。

例 10.6. *看随机 1-SAT 的玩具系综 $\mathrm{SAT}_N(1,\alpha)$：独立以概率 $\alpha/2$ 包含每个文字作为子句，$\alpha \leq 2$。可满足要求每变量的两种文字至多出现一种，所以*

$$P_N(1,\alpha) = (1-\alpha^2/4)^N. \tag{10.14}$$

任意 $\alpha > 0$ 时概率指数趋 0，阈值为 0，而朴素上界为 1。若 SAT，则 $Z(F) = 2^n$，原文称 n 为两种文字均未出现的“子句数”。有

$$\mathbb{P}\{Z(F) = 2^n\} = \binom{N}{n}(1-\alpha/2)^{2n}[\alpha(1-\alpha/2)]^{N-n}. \tag{10.15}$$

对 $n > 0$ 得大偏差形式

$$\mathbb{P}\{Z(F) = 2^{N\nu}\} \doteq \exp[-NI_\alpha(\nu)], \tag{10.16}$$

$$I_\alpha(\nu) \equiv -H(\nu) - (1+\nu)\log(1-\alpha/2) - (1-\nu)\log\alpha. \tag{10.17}$$

[10]译注：式 (10.9) 的右侧依赖 N，应按在两侧区间一致趋于 1 或 0 理解，严格写法可用密度序列 α_N 或相应上确界；原表述不自动证明阈值序列收敛。历史开放性按草稿年代保留。

用鞍点近似间接计算均值：

$$\begin{aligned}\mathbb{E}Z(F) &\doteq \int e^{-NI_\alpha(\nu)+N\nu\log 2}\,d\nu \\ &\doteq \exp\{N\max_{\nu}[-I_\alpha(\nu)+\nu\log 2]\}. \end{aligned} \tag{10.18}$$

极大值在 $\nu^*=1-\alpha/2$。原文写 $I_\alpha(\nu^*)=\log(1-\alpha/2)+(\alpha/2)\log 2>0$，因此 $Z=2^{N\nu^*}$ 的概率指数小；但 $-I_\alpha(\nu^*)+\nu^*\log 2=\log(2-\alpha)>0$（$\alpha<1$），指数大的 Z 克服稀有概率，使均值指数大。

译注： n 应为自由变量数，而非子句数；$0<\alpha<2$ 时上式概率适用于 $0\le n\le N$。从率函数直接代入得 $I_\alpha(\nu^*)=-\log(1-\alpha/2)-(\alpha/2)\log 2>0$，原文的整体符号相反，原值照录。$H$ 在这里须为自然对数的二元熵。$Z=0$ 的不可满足质量不包含在正 Z 率函数里。

习题 10.8. 对 $\mathrm{SAT}_N(K,\alpha)$ 重作定理 *10.5* 的推导，证明得到的上界为 $\alpha=2^K\log 2$，比固定 M 上界差，尽管预期阈值相同。为什么？提示：原文称 M 为参数 N,α 的二项变量；哪些 M 的值主导 $\mathbb{E}Z$？

译注： 按系综定义，$M\sim\mathrm{Bin}(2^K\binom{N}{K},\alpha N/(2^K\binom{N}{K}))$，并非 $\mathrm{Bin}(N,\alpha)$，后者在 $\alpha>1$ 甚至不是合法概率模型。正确第一矩为 $2^N(1-\alpha N/(2^K\binom{N}{K}))^{\binom{N}{K}}$，主导指数给出题中所列界。

改进一阶矩需要更好但仍简单的 U。可数一小类“特殊”满足赋值，保证只要有解便有特殊解，以减小涨落。一种选择是局部极大满足赋值：它满足 F，且任何为 0 的变量单独翻成 1 都会导致不满足。令 U 为这种赋值数。

定理 10.7. 对 $K\ge 2$，令 $\alpha_{\mathrm{UB},2}(K)$ 为方程的唯一正解：

$$\alpha\log(1-2^{-K})+\log\left[2-\exp\left(-\frac{K\alpha}{2^K-1}\right)\right]=0. \tag{10.19}$$

则足够大 N 时，$\alpha_c^{(N)}(K)\le\alpha_{\mathrm{UB},2}(K)$。

证明留给下面习题。

习题 10.9. 取恰有 L 个变量为 *0* 的赋值，不妨为 $x_1,\dots,x_L$。

1. 给定某子句已被赋值 x 满足，若把 x_1 从 *0* 翻为 *1* 会使该子句不满足，称它约束 x_1。证明概率为 $p=\binom{N-1}{K-1}[(2^K-1)\binom{N}{K}]^{-1}$。

2. 给定 x 满足全部子句，x_1 至少被一个子句约束的概率是 $q=1-(1-p)^M$。

3. 令 C_i 为 x_i 被至少一个子句约束的事件。若这些事件条件独立，联合概率为 q^L；实际上不独立。给出启发式理由说明它们反相关，联合概率至多为 q^L，可先看 $L=2$。

4. 证明 $\mathbb{E}U(F)=(1-2^{-K})^M\sum_{L=0}^{N}\binom{N}{L}q^L=(1-2^{-K})^M(1+q)^N$，并在固定 $\alpha=M/N$ 下求渐近，完成证明。

译注：第三项给的是联合概率上界，第四项随之应是 $\leq$，原两处等号照录。启发式反相关还需严格的联合事件控制，不能仅以两两相关符号代替证明。函数关于 0 到 1 方向的局部极大必存在，例如选满足赋值中 1 的数目最多者。阈值序列的渐近上界通常按 $\limsup$ 或任意严格较大密度表述，原无余量的有限 N 不等式需其阈值定义及误差控制。

表 10.1 列出若干 K 的上下界。还可要求翻转两个或更多变量的极大性以小幅改进，但定量改善较小。

10.5.3 下界

大 N 下界主要有两种策略，都利用 Friedgut 定理：要说明阈值不低于 α_*，只需随机公式在相应密度下以不消失概率可满足。

第一种是分析显式寻找满足赋值的启发式算法，证明小于某密度时以正概率成功。最简单的一种用 UCP：有单位子句则满足它并传播；否则从未固定变量均匀选一个，以各 1/2 概率取 0 或 1。出现互补单位子句便失败，全部变量赋值则成功。分析得大 N 时下界

$$\alpha_c^{(N)}(K) \geq \frac{1}{2}\left(\frac{K-1}{K-2}\right)^{K-2}\frac{2^K}{K}.$$

下一题给 $K=3$ 的主要步骤，详细证明见文献。[11]

习题 10.10. 算法迭代 T 次后，令 $\mathcal{C}_s(T)$ 为长度 $s=1,2,3$ 的子句集合，$C_s(T)=|\mathcal{C}_s(T)|$；$\mathcal{V}(T)$ 为未固定变量，$\mathcal{L}(T)$ 为其文字，$|\mathcal{L}(T)|=2(N-T)$。若 T_{halt} 步发现矛盾，约定其后到 N 公式不变。

1. 证明任意 T 时，$\mathcal{C}_s(T)$ 中每子句均匀分布于 $\mathcal{L}(T)$ 上的 s 子句。

2. 证明期望变化为

$$\begin{aligned}\mathbb{E}[C_3(T+1)-C_3(T)] &= -\frac{3C_3(T)}{N-T},\\ \mathbb{E}[C_2(T+1)-C_2(T)] &= \frac{3C_3(T)}{2(N-T)}-\frac{2C_2(T)}{N-T}.\end{aligned}$$

3. 给定 C_1,C_2,C_3，证明

$$C_1(T+1)-C_1(T) \overset{\mathrm{d}}{=} -\mathbb{I}(C_1(T)>0)+\mathcal{B}\left(C_2(T),\frac{1}{N-T}\right),$$

   $\mathcal{B}(n,p)$ 为二项变量。

4. 固定 $t=T/N$ 取大 N，可证明 $C_2/N, C_3/N$ 集中于期望，后者收敛到光滑函数 $c_s(t)$。说明它们满足

$$\frac{dc_3}{dt}=-\frac{3}{1-t}c_3, \qquad \frac{dc_2}{dt}=\frac{3}{2(1-t)}c_3-\frac{2}{1-t}c_2,$$

   并验证 $c_3(t)=\alpha(1-t)^3$、$c_2(t)=(3\alpha/2)t(1-t)^2$。

[11] 译注：此公式针对 $K\geq 3$，并按渐近下界理解；在恰好候选界处，仅非消失满足概率通常需要与尖锐阈值定理及任意严格较低密度配合。

5. 证明单位子句数是 $C_1(0)=0$、$C_1(T+1)-C_1(T)\overset{\mathrm{d}}{=}-\mathbb{I}(C_1(T)>0)+\eta(T)$ 的 *Markov* 过程，$\eta(T)$ 为均值 $c_2(t)/(1-t)$ 的 *Poisson* 变量。给定 C_1 的轨迹及 T，证明截至 T 无矛盾概率为

$$\prod_{\tau=1}^{T}\left(1-\frac{1}{2(N-\tau)}\right)^{[C_1(\tau)-1]\mathbb{I}(C_1(\tau)\geq 1)}.$$

6. 令 $\rho(T)$ 为截至 T 无矛盾概率。取 $T=N(1-\epsilon)$，证明

$$\rho(N(1-\epsilon))\geq\left(1-\frac{1}{2N\epsilon}\right)^{AN+B}\mathbb{P}\left(\sum_{\tau=1}^{N(1-\epsilon)}C_1(\tau)\leq AN+B\right).$$

若所有 $t\in[0,1-\epsilon]$ 都有 $c_2(t)/(1-t)<1$，证明存在 A,B 使右侧概率的大 N 极限“有限”。推出到该时刻仍未矛盾且 $C_1=0$ 的概率有限。

7. 给定尚无矛盾且 $C_1(N(1-\epsilon))=0$，把剩余 *3* 子句各随机删一个变量，变成 *2* 子句。证明 ϵ 足够小时，所得随机 *2-SAT* 密度不超过 $3\epsilon^2/2$，因而可满足。

8. 推出 $\alpha<8/3$ 时，单位子句算法以有限概率找到解。

译注：题中的条件漂移应理解为给定当前历史或计数的期望；已停止后公式冻结，与仍逐次减少的 $N-T$ 及漂移式不能无条件同时成立。第三项产生单位子句的概率按随机未赋文字应为 $1/(N-T)$，但原式忽略已有单位子句被满足或撞成矛盾等有限 N 变化；第五项 Poisson 是大 N 近似，非有限规模精确 Markov 转移。第六项“有限”须指严格正且不消失，单说有限对概率没有约束。第七项按前述解，剩余 2、3 子句总数除以 ϵN 的主阶为 $(3\alpha/2)\epsilon(1-\epsilon)+\alpha\epsilon^2$，非原写的 $3\epsilon^2/2$；它仍在 $\epsilon\to 0$ 时很小。进一步还需把残余可满足性与指定算法后续成功联系，不能把所列步骤当作已无缺口的完整证明。

更精细启发式可给出更好下界。这里转向第二种结构方法，即二阶矩。取 $U(F)$ 在 UNSAT 时为 0、SAT 时严格正，用

$$\mathbb{P}\{F\text{ 为 SAT}\}=\mathbb{P}\{U(F)>0\}\geq\frac{[\mathbb{E}U(F)]^2}{\mathbb{E}[U(F)^2]}. \tag{10.20}$$

它比一阶矩更难实施。直接取 $U=Z$ 没用，*任意非零 α 时比值随 N 指数小。需要涨落较小的 U，使比值在大 N 时不消失。

成功的想法是对满足赋值加权：

$$U(F)=\sum_{x}\prod_{a=1}^{M}W(x,a), \tag{10.21}$$

遍历全部 2^N 个赋值。若 x 不满足子句 a，权重为 0，否则为正。令权重仅依赖 x 下使该子句满足的变量数 $r(x,a)$：

$$W(x,a)=\begin{cases}\varphi(r(x,a)), & r(x,a)\geq 1,\\ 0, & \text{否则.}\end{cases} \tag{10.22}$$

容易求前两矩：

$$\mathbb{E}U(F) = 2^N \left[2^{-K} \sum_{r=1}^{K} \binom{K}{r} \varphi(r) \right]^M , \tag{10.23}$$

$$\mathbb{E}[U(F)^2] = 2^N \sum_{L=0}^{N} \binom{N}{L} [g_\varphi(N,L)]^M . \tag{10.24}$$

其中 $g_\varphi(N,L)$ 是固定恰有 L 个变量相同的两个赋值 x, y，随机选子句 a 时 $W(x,a)W(y,a)$ 的期望。引入二进制向量 $\vec{u}, \vec{v} \in \{0,1\}^K$，$u_s = 1$ 表示 x 下子句第 s 个变量满足子句，否则为 0；$\vec{v}$ 对 y 同样定义。令 $d(\vec{u}, \vec{v})$ 为 Hamming 距离，$w(\vec{u}), w(\vec{v})$ 为 Hamming 重量，则

$$g_\varphi(N,L) = 2^{-K} {\sum_{\vec{u},\vec{v}}}' \varphi(w(\vec{u}))\varphi(w(\vec{v})) \left(\frac{L}{N}\right)^{d(\vec{u},\vec{v})} \left(1 - \frac{L}{N}\right)^{K - d(\vec{u},\vec{v})} . \tag{10.25}$$

撇号表示两向量各至少一个非零分量。特别简单的是 $\varphi(r) = \lambda^r$。令 $z = L/N$，得到原稿写作 g_w 的函数

$$g_w(N,L) = 2^{-K} \left(\left[(\lambda^2 + 1)z + 2\lambda(1-z) \right]^K - 2[z + \lambda(1-z)]^K + z^k \right). \tag{10.26}$$

译注：式 (10.25) 中 L/N 表示相同比例，故距离为 d 的两个局部向量应配 $(L/N)^{K-d}(1-L/N)^d$，原式指数反了。有限 N 无放回选变量还需超几何权重，不是精确的独立乘积。式 (10.26) 的 g_w 与后文 g_φ 记号未统一，末项小写 k 应与子句长 K 对应；原式和后面的 z^k 均保留提示。

用前两矩的式子，主导指数为

$$\mathbb{E}U(F) \doteq e^{N h_1(\lambda,\alpha)}, \qquad \mathbb{E}[U(F)^2] \doteq e^{N \max_z h_2(\lambda,\alpha,z)}, \tag{10.27}$$

极大化区间为 $[0,1]$，其中

$$h_1(\lambda,\alpha) \equiv \log 2 - \alpha K \log 2 + \alpha \log[(1+\lambda)^K - 1], \tag{10.28}$$

$$\begin{aligned} h_2(\lambda,\alpha,z) \equiv{}& \log 2 - z\log z - (1-z)\log(1-z) - \alpha K \log 2 \\ &+ \alpha \log \left(\left[(\lambda^2+1)z + 2\lambda(1-z) \right]^K - 2[z + \lambda(1-z)]^K + z^k \right). \end{aligned} \tag{10.29}$$

代入 $z = 1/2$ 得 $h_2(\lambda,\alpha,1/2) = 2h_1(\lambda,\alpha)$。这对应二阶矩由完全不相关的赋值主导：两个均匀随机赋值约一半变量相同，期望因子化为 $\mathbb{E}U^2 \approx (\mathbb{E}U)^2$。有两种可能：

1. 若极大值不是仅在 $z = 1/2$，原文称 $\max_z h_2 > 2h_1$ 严格成立，比值指数小，二阶矩不等式无用。

2. 若仅在 $z = 1/2$ 极大，比值主导指数为 1。进一步求指数前因子，可得比值大 N 时保持有限，由此 $\alpha \leq \alpha_c^{(N)}(K)$。

译注：第一项还漏掉其他点与 $1/2$ 并列同高的情形，“不唯一” 不必意味着严格更大。第二项的关键是比值有严格正下界，不是仅有有限上界；只知道主导指数相同或唯一极大，还需曲率非退化、边界及次主导误差控制，才能认证非消失比值。

表 10.1: 随机 K-SAT 可满足性阈值的界。下界来自定理 10.8，上界为式 (10.13)、(10.19)。数值按原表保留。

K	3	4	5	6	7	8	9	10
α_{LB}	2.548	7.314	17.62	39.03	82.63	170.6	347.4	701.5
$\alpha_{\mathrm{UB},1}$	5.191	10.74	21.83	44.01	88.38	177.1	354.5	709.4
$\alpha_{\mathrm{UB},2}$	4.666	10.22	21.32	43.51	87.87	176.6	354.0	708.9

第二种情况的必要条件是 $z = 1/2$ 为局部极大，要求 λ 为方程的唯一严格正根：

$$(1+\lambda)^{K-1} = \frac{1}{1-\lambda}. \tag{10.30}$$

因而得到：

定理 10.8. *令 λ 为式 (10.30) 的正根，h_2 如式 (10.29)。若 $z \in [0,1]$ 上极大值仅在 $1/2$ 达到，则随机 $\mathrm{SAT}_N(K,\alpha)$ 公式以趋于 1 的概率可满足。*

令 $\alpha_{\mathrm{LB}}(K)$ 为满足假设的最大 α，便有大 N 下界 $\alpha_c^{(N)}(K) \geq \alpha_{\mathrm{LB}}(K)$，若干值见表 10.1。大 K 可证明

$$\alpha_{\mathrm{LB}}(K) = 2^K \log 2 - 2(K+1)\log 2 - 1 + o(1), \tag{10.31}$$

$$\alpha_{\mathrm{UB},1}(K) = 2^K \log 2 - \frac{1}{2}\log 2 + o(1). \tag{10.32}$$

本章简单方法使阈值的相对误差按 2^{-K} 衰减；有限 K 的精确结果需要后续章节的更精细工具。**译注：** 严格正根针对 $K \geq 3$，另有平凡根 $\lambda = 0$，$K = 2$ 没有非零正根。所列矩计算首先针对固定 M，原定理写 Bernoulli 系综，跨系综和从正概率到高概率的阈值提升须在严格较低密度留出余量；单独的二阶矩界不直接给同一点的概率趋 1。“最大值” 还可能只有上确界。所列大 K 渐近界及研究问题的权重最优性仍按草稿保留，此处未重新完成其严格证明。由上下界差 $O(K)$、阈值主阶 $O(2^K)$，直接得到相对误差 $O(K2^{-K})$，原文略去了多项式 K 因子。

习题 10.11 (研究问题)**.** *证明权重 $\varphi(r) = \lambda^r$ 最优：其他选择给出更差下界。还可采用什么策略进一步改进？*

注释

Gu、Purdom、Franco 和 Wah（2000）的综述全面介绍可满足性算法，也列出详细应用及参考文献。Davis 和 Putnam（1960） 的算法系统使用归结规则；正文的回溯算法由 Davis、Logemann 和 Loveland（1962） 引入。

还研究过其他随机 CNF 系综，但困难公式不容易生成。例如独立生成 M 个子句，每个变量以各 $p \leq 1/2$ 概率以正、负文字出现，以 $1-2p$ 概率不出现。请读者研究这一系综，*Franco (2000) 提供入门及文献导引。另一个有用系综是 “$2+p$” SAT，取 pM 个 3 子句和 $(1-p)M$ 个 2 子句，在 2-SAT 与 3-SAT 间插值，见 Monasson、Zecchina、Kirkpatrick、Selman 和 Troyansky（1999）。

Cook（1971） 讨论 2-SAT 的多项式性；Garey、Johnson 和 Stockmeyer（1976） 证明 MAX-2-SAT 为 NP 完全。[12] Schöning（1999） 提出随机游走算法，Schöning（2002） 进一步讨论；更一般策略见 Papadimitriou（1991）、Selman 和 Kautz（1993）、Selman、Kautz 和 Cohen（1994）。

Chvátal 和 Reed（1992）、Goerdt（1996）、de la Vega（1992） 证明随机 2-SAT 阈值 1，亦见 de la Vega（2001）。Bollobas、Borgs、Chayes、Kim 和 Wilson（2001）用图论分析阈值附近标度。Kirkpatrick 和 Selman 最早数值识别随机 3-SAT 相变及附近的困难实例（Kirkpatrick 和 Selman，1994；Selman 和 Kirkpatrick，1996），亦见 Selman、Mitchell 和 Levesque（1996）。Friedgut（1999） 证明尖锐阈值定理。

阈值上界见 Dubois 和 Boufkhad（1997）、Kirousis、Kranakis、Krizanc 和 Stamatiou（1998）。Chao 和 Franco 开创通过算法分析给下界；Chao 和 Franco（1986）对应习题 10.10，1990 年的工作作推广。Achlioptas（2001）综述此类方法，Cocco、Monasson、Montanari 和 Semerjian（2003）综述基于物理的算法分析。加权二阶矩下界思想见 Achlioptas 和 Moore（2005），这里讨论的界来自 Achlioptas 和 Peres（2004），该论文也解答习题 10.11 的第一个问题。约束满足问题二阶矩的简单介绍见 Achlioptas、Naor 和 Peres（2005），亦见 Gomes 和 Selman（2005）。[13]

[12]译注：这里的 NP 完全应对应其带目标违反数阈值的判定版本；优化版本通常称 NP 困难。

[13]译注：保留作者—年份引用，书目年份差异见书后说明，历史优先性依原草稿归属。

第十一章　低密度奇偶校验码

低密度奇偶校验（low-density parity-check，LDPC）纠错码由 Robert Gallager 于 1963 年在博士论文中提出。基本动机来自这样一个观察：随机线性码（参见第 “??” 节）理论性能优异，却不实用，尤其当时没有已知的高效解码算法。回头看，这并不意外，因为后来人们证明，线性码的解码是一个 NP 困难问题。[1]

于是，人们想到对随机线性码系综加以限制。如果得到的码有足够的结构，就可能利用这些结构构造高效解码算法。这当然有代价：限制系综可能损害性能。Gallager 的建议简单而成功，却超前于时代：LDPC 码是当今效率最高的一类码。

本章介绍一类最重要的 LDPC 系综，并推导若干基本性质。和任何码一样，可以从两个截然不同的角度研究。第一种是研究最优解码下的性能，[2]对解码过程的计算复杂度不作限制，例如允许扫描整个指数规模的码本。第二种则分析某种具体高效解码算法下的性能。依应用不同，可以只要求算法具有多项式复杂度，也可能要求复杂度随块长线性增长。

这里主要讨论最优解码下的性能。我们将推导严格界，说明适当选择的 LDPC 系综允许以接近 Shannon 容量的码率可靠通信。然而，LDPC 码的主要意义在于可以高效解码，我们也会讨论一种线性时间解码算法的简单例子。最优解码下 LDPC 码的完整研究推迟到第 “??” 章；更精细的解码算法将在第 “??” 章介绍和分析。

第 11.1 节定义 LDPC 码及其系综，第 11.2 节讨论码本的若干几何性质。第 11.3 节利用这些性质给出可靠通信阈值的下界，并从信息论考虑得到上界。第 11.4 节讨论一种简单解码算法，证明它能纠正有限比例的错误。

11.1　定义

11.1.1　布尔线性代数

回忆，一个码由其码本 $\mathcal{C} \subset \{0,1\}^N$ 刻画。LDPC 码是*线性码*，即码本是 $\{0,1\}^N$ 的线性子空间。实际中可用一个 $M \times N$ 矩阵 H 指定这一子空间，其中 $H_{ij} \in \{0,1\}$ 且 $M < N$。码本定义为 H 的核：

$$\mathcal{C} = \{x \in \{0,1\}^N : Hx = 0\}. \tag{11.1}$$

[1]译注：本章原有未定章节引用均保留问号，不猜补章号；关于一般线性码的困难性是最坏情形结论，并不排除特定码族的高效解码。

[2]可以关注不同性能参数，如比特或块错误率、信息容量等。相应的 “最优” 解码策略也可能不同，例如符号 MAP、码字 MAP 等。作为初步近似，性能判据的选择并非关键；我们会尽可能保持讨论的一般性。

这里及本章以下，Hx 中的乘法和加法都按模 2 计算。矩阵 H 称为码的奇偶校验矩阵。码本大小为 $2^{N-\mathrm{rank}(H)}$，其中 $\mathrm{rank}(H)$ 是矩阵的秩，即线性无关行的数目。由于 $\mathrm{rank}(H)\le M$，有 $|\mathcal{C}|\ge 2^{N-M}$。稍微改变第 1 章的记号，令 $L\equiv N-M$。码率因此满足 $R\ge L/N$，当 H 的所有行线性无关时取等号。

给定这样的码，编码总可实现为线性运算。存在一个 $N\times L$ 的二元矩阵 G（生成矩阵），使码本为其像：$\mathcal{C}=\{x=Gz:z\in\{0,1\}^L\}$。编码就是映射 $z\mapsto x=Gz$。注意 HG 是一个所有元素均为零的 $M\times L$ 零矩阵。[3]

11.1.2 因子图

例 9.5 描述了一个具体线性码（Hamming 码）的因子图。已知 H 时，构造方法如下：记 $i^a_1,\dots,i^a_{k(a)}\in\{1,\dots,N\}$ 为第 a 行中矩阵元等于 1 的列指标。于是向量 Hx 的第 a 个分量为 $x_{i^a_1}\oplus\cdots\oplus x_{i^a_{k(a)}}$。记 $P_H(x)$ 为码 H 的所有码字上的均匀分布，以下常将码与其校验矩阵等同。它为

$$P_H(x)=\frac{1}{Z}\prod_{a=1}^{M}\mathbb{I}(x_{i^a_1}\oplus\cdots\oplus x_{i^a_k}=0). \tag{11.2}$$

因此，$P_H(x)$（或 H）的因子图包含 N 个变量节点，每列一个；以及 M 个函数节点，在这里也称校验节点，每行一个。当对应矩阵元非零时，函数节点与变量节点之间有边。这个过程显然可逆：对任意含 N 个变量节点和 M 个函数节点的因子图，都可关联一个 $M\times N$ 二元矩阵 H，称为图的邻接矩阵，其非零元对应图中的边。

11.1.3 给定度分布的系综

第 9 章引入了因子图系综 $\mathcal{D}_N(\Lambda,P)$。它有 N 个变量节点，两个多项式 $\Lambda(x)=\sum_{n=0}^{\infty}\Lambda_n x^n$、$P(x)=\sum_{n=0}^{\infty}P_n x^n$ 定义度分布：Λ_n 是随机选取的变量节点度为 n 的概率，P_n 是随机选取的函数节点度为 n 的概率。为排除平凡情形，总假设变量节点度至少为 1，函数节点度至少为 2。校验节点数和变量节点数满足 $M=N\Lambda'(1)/P'(1)$。

将 $\mathcal{D}_N(\Lambda,P)$ 中随机图的邻接矩阵作为校验矩阵，所得码系综记为 $\mathrm{LDPC}_N(\Lambda,P)$。我们关心固定度分布下的 $N\to\infty$ 极限，此时每个顶点通常只连接其他顶点中趋于零的比例，故称“低密度”。比值 $L/N=(N-M)/N=1-\Lambda'(1)/P'(1)$ 是实际码率 R 的下界，称为码或系综的设计码率 R_{des}。实际码率当然是随机变量，但下面会看到，它一般紧密集中于 R_{des} 附近。

常见特例是具有固定度的正则图：所有变量节点度为 l，所有函数节点度为 k，即 $P(x)=x^k$、$\Lambda(x)=x^l$。对应系综通常简记为 $\mathrm{LDPC}_N(l,k)$ 或 (l,k)，设计码率为 $R_{\mathrm{des}}=1-l/k$。

从 $\mathcal{D}_N(\Lambda,P)$ 均匀抽取随机图并不简单。最直接的变通方法，是以一个略有不同、但可用简单算法描述的系综替代均匀系综。例如，先将变量节点集均匀随机划分为大小为 $N\Lambda_0,N\Lambda_1,\dots,N\Lambda_{l_{\max}}$ 的子集，分别给其中各节点分配 0、1、……、$l_{\max}$ 个“插口”。同样，将校验节点集分为大小为 $MP_0,MP_1,\dots,MP_{k_{\max}}$ 的子集，分别给节点分配 0、1、……、$k_{\max}$ 个插口。两侧的插口总数均为 $N\Lambda'(1)$。在这些对象上抽取均匀随机置换，据此连接两侧插口。

[3]译注：原文这里仍使用 $L=N-M$。若 H 不满行秩，则 $\dim\mathcal{C}=N-\mathrm{rank}(H)>L$，$N\times L$ 矩阵的像不能覆盖整个码本。生成矩阵列数应取实际维数，或额外假设 H 满行秩；原陈述照录。

习题 11.1. 上述采样需要两个子程序：将 N 个对象均匀划分为规定大小的子集，以及在 $N\Lambda'(1)$ 个对象上抽取随机置换。证明在可以调用随机数发生器时，两项任务均可用 $O(N)$ 次操作完成。

这个过程有两个缺点：(i) 不同因子图可能对应不同数目的置换，因而不会在 $\mathcal{D}_N(\Lambda,P)$ 上均匀采样；(ii) 可能在同一对节点之间产生重边。

为解决后一问题，约定任意两节点间若有 n 条边，则 n 偶数时全部删去，n 奇数时替换为一条边。所得图不一定仍有规定的度分布，即使条件于它恰有此分布，分布也并不均匀。不过，我们仍用 $\mathrm{LDPC}_N(\Lambda,P)$ 表示这一系综。直觉上，大 N 时实际度分布接近规定分布，对这里的用途而言分布“几乎均匀”；而且真正重要的是实际实现的系综。

习题 11.2. 证明大 N 时上述显式构造产生的度分布接近规定分布。

(i) 记图中出现的重边数为 m，计算其期望。证明固定 Λ,P、$N\to\infty$ 时 $\mathbb{E}m=O(1)$。

(ii) 记上述过程产生的度分布为 (Λ',P')，用

$$d\equiv\sum_l|\Lambda_l-\Lambda'_l|+\sum_k|P_k-P'_k| \tag{11.3}$$

表示规定与实际度分布间的“距离”。由 m 给出 d 的上界，并证明 $\mathbb{E}d=O(1/N)$。

11.2 码本的几何

第 6.2 节介绍过，纠错码的经典分析方法之一是研究码本的几何性质。例如，距离枚举函数 $\mathcal{N}_{x_0}(d)$ 给出与 x_0 的 Hamming 距离为 d 的码字数。对线性码，它不依赖参考码字 x_0；请读者证明这一简单结论。⋆因此习惯上取全零码字为参考，称 $\mathcal{N}(w)=\mathcal{N}_{x_0}(d=w)$ 为权重枚举函数，即权重（码字中 1 的个数）为 w 的码字数。

本节估计 $\mathrm{LDPC}_N(\Lambda,P)$ 中随机码的平均权重枚举函数 $\overline{\mathcal{N}}(w)\equiv\mathbb{E}\mathcal{N}(w)$。与第 6.2 节的随机码系综一样，一般预期它随块长指数增长，大多数码字的权重 $w=N\omega$ 随 N 线性增长。我们要计算指数增长率 $\phi(\omega)$：

$$\overline{\mathcal{N}}(w=N\omega)\doteq e^{N\phi(\omega)}. \tag{11.4}$$

用无序系统的术语说，这是一个“退火平均”，可能被系综中的罕见实例主导。另一方面，预期 $\log\mathcal{N}(w)$ 紧密集中在典型值 $N\phi_{\mathrm{q}}(\omega)$ 附近。典型指数可通过淬火计算求得，例如考察

$$\lim_{N\to\infty}N^{-1}\mathbb{E}\log[1+\mathcal{N}(w)].$$

对数的凹性给出 $\phi_{\mathrm{q}}(\omega)\le\phi(\omega)$。这里仅作更简单且给出上界的退火计算，淬火计算留到第“???”章。[4]

对长度 N、权重 w 的二元串 x，$Hx=0\pmod 2$ 当且仅当因子图满足以下性质：将所有 $x_i=1$ 的变量节点所接的边涂红，其余涂蓝，则每个校验节点所接红边数必须为偶数。稍作思考可知，$\overline{\mathcal{N}}(w)$ 等于满足条件的着色因子图数除以系综中因子图总数。先计算固定度 (l,k) 的情形，再推广到任意度分布。

[4]译注：$\log[1+\mathcal{N}(w)]\ge 0$，它在无典型码字的区域只能给出零，而退火指数 ϕ 可以为负。因此这里对 ϕ_{q} 的两种表述及无条件不等式需区分定义域与正部截断；原文照录。

11.2.1 权重枚举函数：固定度

有 N 个度为 l 的变量节点和 M 个度为 k 的函数节点，总边数记为 $F = Mk = Nl$。合法着色图必须有 $E = wl$ 条红边。先以 $\binom{N}{w}$ 种方式选择 w 个变量节点，给它们各配 l 个红插口，其余节点各配 l 个蓝插口。再给每个函数节点的一个偶数大小插口子集涂红，使红插口总数为 lw。记有 r 个红插口的函数节点数为 m_r；只有偶数 r 时 m_r 可非零，且 $\sum_{r=0}^{k} m_r = M$、$\sum_{r=0}^{k} r m_r = lw$。函数节点插口的着色方式数为

$$C(k,M,w) = \sum_{m_0,\dots,m_k}^{(e)} \binom{M}{m_0,\dots,m_k} \prod_r \binom{k}{r}^{m_r} \times \mathbb{I}\left(\sum_{r=0}^{k} m_r = M\right) \mathbb{I}\left(\sum_{r=0}^{k} r m_r = lw\right). \tag{11.5}$$

$\sum^{(e)}$ 表示只有偶数 r 的 m_r 可非零。最后按颜色匹配两侧插口，合法匹配数为 $(lw)!(F-lw)!$，全部匹配数为 $F!$。合起来得到

$$\overline{\mathcal{N}}(w) = \frac{(lw)!(F-lw)!}{F!} \binom{N}{w} C(k,M,w). \tag{11.6}$$

要计算式 (11.4)，需在固定 $\omega = w/N$、$N \to \infty$ 时求其渐近行为。令 $m_r = x_r M = x_r N l/k$，用 Stirling 公式展开多项式系数，得

$$\phi(\omega) = \max_{\{x_r\}}^{*} \left[(1-l)\mathcal{H}(\omega) + \frac{l}{k} \sum_r \left(-x_r \log x_r + x_r \log \binom{k}{r} \right) \right]. \tag{11.7}$$

$\max^*$ 对 $x_0, x_2, x_4, \dots \in [0,1]$ 取极大，约束为 $\sum_r x_r = 1$、$\sum_r r x_r = k\omega$。引入两个 Lagrange 乘子，得 $x_r = C z^r \binom{k}{r} \mathbb{I}(r\text{为偶数})$，其中 C, z 由约束确定：

$$C = \frac{2}{(1+z)^k + (1-z)^k}, \tag{11.8}$$

$$\omega = z \frac{(1+z)^{k-1} - (1-z)^{k-1}}{(1+z)^k + (1-z)^k}. \tag{11.9}$$

将 x_r 代回 ϕ 的表达式（原文此处引用下式），最终得到

$$\phi(\omega) = (1-l)\mathcal{H}(\omega) + \frac{l}{k} \log \frac{(1+z)^k + (1-z)^k}{2} - \omega l \log z, \tag{11.10}$$

其中 z 由式 (11.9) 定义。下面会使用这个结果，先说明其推广。

11.2.2 权重枚举函数：一般情形

对一般 $\mathrm{LDPC}_N(\Lambda, P)$ 码，我们计算 $\overline{\mathcal{N}}(w) \doteq \exp[N\phi(\omega)]$ 的主导指数行为。思路与正则情形相同，计算略繁，故采用紧凑记号。本小节技术性较强，不关心细节的读者可直接阅读结果。

设合法着色图的红边数为 E，它不再由 w 唯一确定。选出 w 个度数总和为 E 的变量节点的方式数为 $\mathrm{coeff}[\prod_l (1+xy^l)^{N\Lambda_l}, x^w y^E]$。[5]像前面一样，每个函数节点的红插口数为偶数，总

[5]记号 $\mathrm{coeff}[f(x), x^n]$ 表示形式幂级数 $f(x)$ 中 x^n 的系数。

红插口数为 E，方式数为 $\mathrm{coeff}[\prod_k q_k(z)^{MP_k}, z^E]$，其中 $q_k(z) \equiv \frac{1}{2}(1+z)^k + \frac{1}{2}(1-z)^k$。两侧红插口匹配数仍为 $E!(F-E)!$，总边数为 $F = N\Lambda'(1) = MP'(1)$。因此精确结果为

$$\overline{\mathcal{N}}(w) = \sum_{E=0}^{F} \frac{E!(F-E)!}{F!} \times \mathrm{coeff}\left[\prod_{l=1}^{l_{\max}} (1+xy^l)^{N\Lambda_l}, x^w y^E\right] \mathrm{coeff}\left[\prod_{k=2}^{k_{\max}} q_k(z)^{MP_k}, z^E\right]. \tag{11.11}$$

在 $w = N\omega$ 时令 $E = F\xi = N\Lambda'(1)\xi$，用鞍点法估计两个系数项。以下概述第二项的计算。由 Cauchy 定理，

$$\begin{aligned} \mathrm{coeff}\left[\prod_{k=2}^{k_{\max}} q_k(z)^{MP_k}, z^E\right] &= \oint \frac{1}{z^{N\Lambda'(1)\xi+1}} \prod_{k=2}^{k_{\max}} q_k(z)^{MP_k} \frac{dz}{2\pi i} \\ &\equiv \oint \frac{f(z)^N}{z} \frac{dz}{2\pi i}, \end{aligned} \tag{11.12}$$

积分沿复 z 平面中绕原点的任意闭路进行，且

$$f(z) \equiv \frac{1}{z^{\Lambda'(1)\xi}} \prod_{k=2}^{k_{\max}} q_k(z)^{\Lambda'(1)P_k/P'(1)}. \tag{11.13}$$

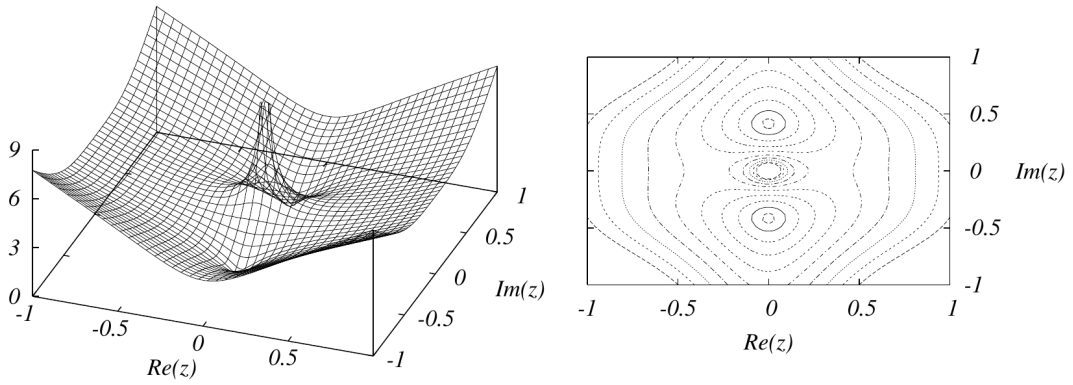


图 11.1: $\xi = 1/3$ 时函数 $z^{-3\xi} q_4(z)^{3/4}$ 的模。取自 Part C PDF 第 54 页（原 222）。

图 11.1 画出了 $\Lambda(x) = x^3$、$P(x) = x^4$、$\xi = 1/3$ 时 $f(z)$ 的模。函数有一个位于 $z_* = z_*(\xi) \in \mathbb{R}_+$ 的鞍点，满足 $f'(z) = 0$，即

$$\xi = \sum_{k=2}^{k_{\max}} \rho_k z \frac{(1+z)^{k-1} - (1-z)^{k-1}}{(1+z)^k + (1-z)^k}. \tag{11.14}$$

这里使用第 9.5 节的记号 $\rho_k = kP_k/P'(1)$；类似地记 $\lambda_l = l\Lambda_l/\Lambda'(1)$。这推广了式 (11.9)。若式 (11.12) 的积分路径取为半径 z_* 的圆，积分由 z_* 及其对称点 $-z_*$ 的鞍点贡献主导，于是

$$\mathrm{coeff}\left[\prod_{k=2}^{k_{\max}} q_k(z)^{MP_k}, z^E\right] \doteq \exp\left\{N\left[-\Lambda'(1)\xi \log z_* + \frac{\Lambda'(1)}{P'(1)} \sum_{k=2}^{k_{\max}} P_k \log q_k(z_*)\right]\right\}.$$

译注： 每个 q_k 都是偶多项式，故奇数 E 的系数严格为零。鞍点指数式须用于非零的可行系数子序列，不能忽略对称鞍点相消或权重的奇偶约束。

原文接着说，对式 (11.11) 中“第二个”系数项作类似处理，得 $\overline{\mathcal{N}}(w=N\omega)\doteq\exp\{N\phi(\omega)\}$，其中

$$\phi(\omega)=\sup_{\xi}\inf_{x,y,z}\Big\{-\Lambda'(1)\mathcal{H}(\xi)-\omega\log x-\Lambda'(1)\xi\log(yz) + \sum_{l=2}^{l_{\max}}\Lambda_l\log(1+xy^l)+\frac{\Lambda'(1)}{P'(1)}\sum_{k=2}^{k_{\max}}P_k\log q_k(z)\Big\}. \tag{11.15}$$

对 x,y,z 的极小化沿正实轴进行，$\xi\in[0,1]$。关于 z 的驻点条件由式 (11.14) 给出。关于 ξ,x,y 的驻点条件依次为

$$\xi=\frac{yz}{1+yz},\qquad \omega=\sum_{l=1}^{l_{\max}}\Lambda_l\frac{xy^l}{1+xy^l},\qquad \xi=\sum_{l=1}^{l_{\max}}\lambda_l\frac{xy^l}{1+xy^l}. \tag{11.16}$$

译注： 刚才已经处理了第二个系数项，因此原文再次写“第二个”应核查为第一个。式 (11.15) 的变量度求和从 $l=2$ 起，而前后精确式和驻点式从 $l=1$ 起；允许 $\Lambda_1>0$ 时不可漏掉该项。此处保留原下限。$\mathcal{H}$ 在这些自然指数公式中按自然对数的二元熵理解。

用第一式消去 ξ，得到以 $x\in[0,\infty)$ 为参数的最终表示：

$$\phi(\omega)=-\omega\log x-\Lambda'(1)\log(1+yz)+\sum_{l=1}^{l_{\max}}\Lambda_l\log(1+xy^l) + \frac{\Lambda'(1)}{P'(1)}\sum_{k=2}^{k_{\max}}P_k\log q_k(z), \tag{11.17}$$

$$\omega=\sum_{l=1}^{l_{\max}}\Lambda_l\frac{xy^l}{1+xy^l}, \tag{11.18}$$

其中 $y=y(x)$、$z=z(x)$ 满足耦合方程

$$y=\frac{\sum_{k=2}^{k_{\max}}\rho_k p_k^{-}(z)}{\sum_{k=2}^{k_{\max}}\rho_k p_k^{+}(z)},\qquad z=\frac{\sum_{l=1}^{l_{\max}}\lambda_l xy^{l-1}/(1+xy^l)}{\sum_{l=1}^{l_{\max}}\lambda_l/(1+xy^l)}, \tag{11.19}$$

并定义 $p_k^{\pm}(z)\equiv[(1+z)^{k-1}\pm(1-z)^{k-1}]/[(1+z)^k+(1-z)^k]$。

习题 11.3. 式 (11.18)、(11.19) 的数值求解可能颇为棘手。下面是一种似乎效果不错的简单迭代方法，至少在作者探索过的所有情形中如此。请用自己喜欢的度分布 Λ,P 试验。

先给定 $y\in[0,\infty)$、$\omega\in[0,1]$，用二分法从式 (11.18) 解出 x；代入式 (11.19)，将所得方程写成 $y=f(z)$、$z=g(y,\omega)$。定义 $F_\omega(y)\equiv f(g(y,\omega))$，迭代映射 $y_{n+1}=F_\omega(y_n)$ 以求解 $y=F_\omega(y)$。找到不动点 y_* 后，令 $z_*=g(y_*,\omega)$，再从 $y=y_*$ 时的式 (11.18) 求 x_*。最后代入式 (11.17) 得 $\phi(\omega)$。

图 11.2、11.3、11.4 给出若干 ϕ 的例子。下面讨论这些结果，特别关注小 ω 区域。

11.2.3 短距离性质

低噪声极限中，码的性能很大程度上取决于是否存在距离发送码字很近的其他码字。对线性码与对称信道，可以不失一般性地假设发送全零码字。这里求若干 LDPC 系综在短距离，即小权重 ω 下的 $\phi(\omega)$，并在第 11.3 节用于刻画性能。

当 $\omega \to 0$ 时，式 (11.18)、(11.19) 的解满足 $y, z \to 0$。Taylor 展开给出

$$y \simeq \rho'(1) z, \qquad z \simeq \lambda_{l_{\min}} x y^{l_{\min}-1}, \qquad \omega \simeq \Lambda_{l_{\min}} x y^{l_{\min}}. \tag{11.20}$$

这里略去了 y, z 的高阶项。需区分 $l_{\min} = 1$、2 或至少 3。

先考虑 $l_{\min} = 1$。此时 x, y, z 都按 $\sqrt{\omega}$ 缩放，稍作计算得

$$\phi(\omega) = -\frac{1}{2}\omega \log(\omega/\Lambda_1^2) + O(\omega). \tag{11.21}$$

因此足够小的 ω 下 ϕ 严格为正，与给定码字相距很小但仍为 $\Theta(N)$ 的 Hamming 距离内，平均有指数多个码字。这让人想到没有任何奇偶校验的情形，此时 $\phi(\omega) = \mathcal{H}(\omega) \simeq -\omega \log \omega$。

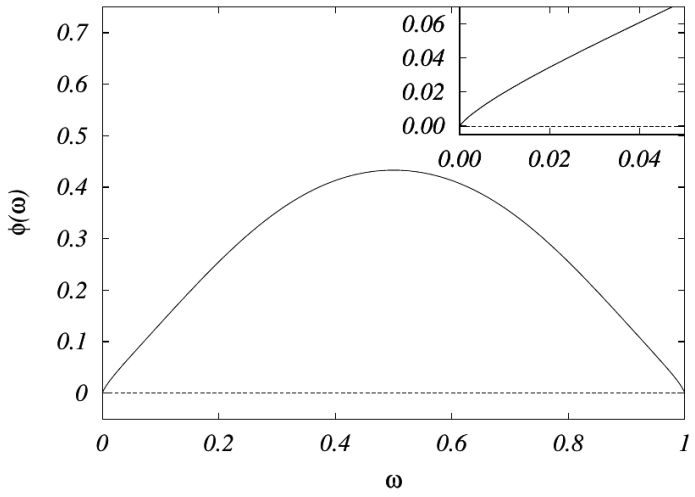


图 11.2: 系综 $\mathrm{LDPC}_N(\frac{1}{4}x + \frac{1}{4}x^2 + \frac{1}{2}x^3, x^6)$ 的平均权重枚举函数的对数指数 $\phi(\omega)$，横轴为约化权重 $\omega = w/N$。插图为小权重区；原点附近 $\phi > 0$，且导数在 $\omega \to 0$ 时发散，每个码字周围有大量距离很近的其他码字，使其纠错性能很差。取自 Part C PDF 第 57 页（原 225）。

习题 11.4. 为检验式 (11.21)，计算正则系综 $\mathrm{LDPC}_N(l = 1, k)$ 的权重枚举函数。注意它不依赖码的具体实现，且有简单表示 $\mathcal{N}(w) = \mathrm{coeff}[q_k(z)^{N/k}, z^w]$。

图 11.2 是 $l_{\min} = 1$ 的一个非正则例子。式 (11.21) 对纠错很不利。暂时忽略它是在 $N \to \infty$ 后再取 $\omega \to 0$ 得到的，将它用于固定 $w = N\omega$、$N \to \infty$ 的区域，得

$$\overline{\mathcal{N}}(w) \sim \left(\frac{N}{w}\right)^{w/2}. \tag{11.22}$$

结果不仅在平均意义下成立，对系综中大多数码也成立。也就是说，在距任意给定码字仅 2 的 Hamming 距离处，就已有 $\Theta(N)$ 个其他码字。由含噪声观测区分两个相距 $\Theta(1)$ 的码字，大多

数情形下显然是不可能的。因此通常不将 $l_{\min}=1$ 的系综用于纠错。[6]

现在取 $l_{\min}=2$。由式 (11.20)，

$$\phi(\omega)\simeq A\omega, \qquad A\equiv \log\left[\frac{P''(1)}{P'(1)}\frac{2\Lambda_2}{\Lambda'(1)}\right]=\log[\rho'(1)\lambda'(0)]. \tag{11.23}$$

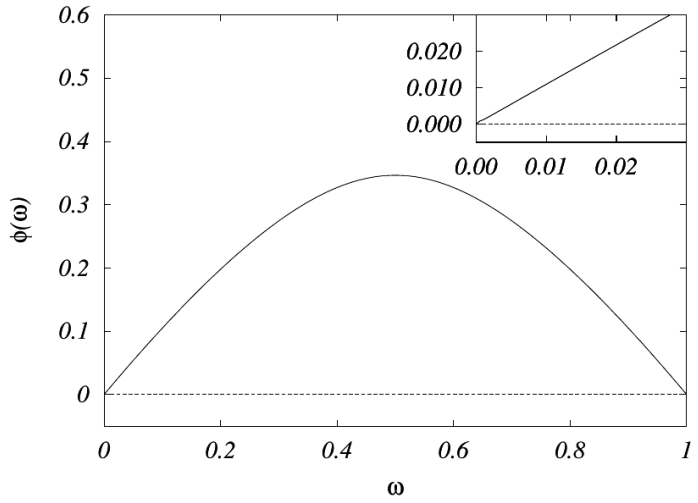


图 11.3: $\mathrm{LDPC}_N(2,4)$ 系综的平均权重枚举函数的对数指数。$\Lambda(x)=x^2$，所有变量节点度为 2；原图注写 $P(x)=4$，所有函数节点度为 4。插图为小权重区。$A>0$，因而有短距离码字。取自 Part C PDF 第 58 页（原 226）。

译注： 图注的 $P(x)=4$ 按原文保留；度为 4 的生成多项式应为 x^4。

系综性质强烈依赖 A 的符号。若 $A>0$，与给定码字相距很小但仍为 $\Theta(N)$ 的距离内，平均码字数随块长指数增长，似乎与 $l_{\min}=1$ 相似。不过此时 $\phi(\omega)$ 趋零快得多。再假定式 (11.23) 在其推导的渐近区域外仍成立，得

$$\overline{\mathcal{N}}(w)\sim e^{Aw}. \tag{11.24}$$

换言之，直到 Hamming 距离 $d_*\simeq \log N/A$，任意码字周围的码字数仍为 $o(N)$。对许多用途，d_* 起 “有效” 最小距离的作用。图 11.3 是 $A=\log 3$ 的正则 $(2,4)$ 码。

若 $A<0$，则某个区间 $\omega\in(0,\omega_*)$ 内 $\phi(\omega)<0$。一阶矩法说明，对其中任意 ω，不存在权重接近 $N\omega$ 的码字。$l_{\min}\geq 3$ 时有相似结论，此时

$$\phi(\omega)\simeq \frac{l_{\min}-2}{2}\,\omega\log\left(\frac{\omega}{\Lambda_{l_{\min}}}\right). \tag{11.25}$$

短距离性质良好的 $(3,6)$ 码见图 11.4。上述讨论可归纳为：

命题 11.1. *考虑 $\mathrm{LDPC}_N(\Lambda,P)$ 中的随机线性码，设 $l_{\min}\geq 2$ 且 $[P''(1)/P'(1)][2\Lambda_2/\Lambda'(1)]<1$。令 $\omega_*\in(0,1/2)$ 为 ϕ 的第一个非平凡零点。对任意区间 $[\omega_1,\omega_2]\subset(0,\omega_*)$，以高概率不存在距离属于该区间的码字对。*

[6]译注：这里 “不可能” 是原文的直观表述；固定距离下错误概率通常不会随块长趋零，并非任何单次观测均无法区分。式 (11.22) 的外推亦不应单凭固定 ω 的指数渐近式视为严格等价。

译注： 原命题将距离写成属于无量纲区间 $[\omega_1,\omega_2]$；按上下文指约化距离 d/N，或等价地实际距离在 $[N\omega_1,N\omega_2]$。原句照录。

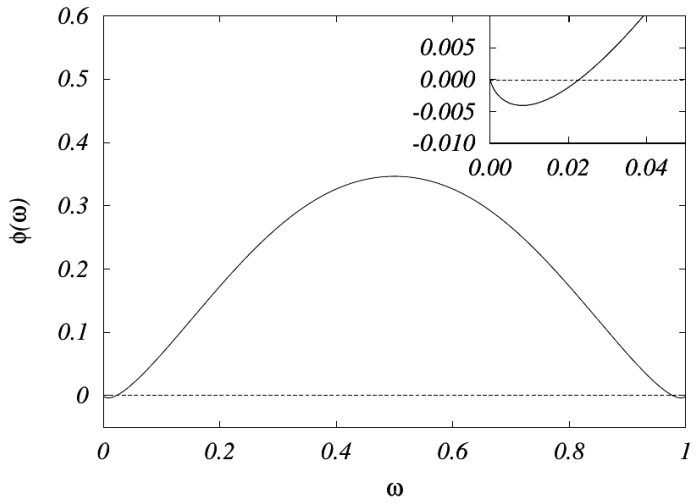


图 11.4: $\mathrm{LDPC}_N(3,6)$ 的平均权重枚举函数的对数指数；插图为小权重区。$\omega<\omega_*\sim 0.02$ 时 $\phi<0$；原图注称，除全零码字外该区域没有码字。此为下述渐近意义的陈述。取自 Part C PDF 第 59 页（原 227）。

上述研究仅涉及随 N 线性增长的权重 $w=N\omega$。命题排除了任意小的固定 ω，却未说明次线性权重 $w=o(N)$，例如 $N\to\infty$ 时 w 有限的情形。事实上，若 $l_{\min}\geq 3$，以高概率也没有这样的码字，最小距离至少为 $N\omega_*$。若 $l_{\min}=2$，通常有有限权重码字；不过在 $A<0$ 时，可通过“剔除”过程消除它们而不改变码率。[7]

11.2.4 码率

权重枚举函数还能精确刻画码率。$\omega=1/2$ 时，$x=y=z=1$ 满足式 (11.18)、(11.19)，给出

$$\phi(1/2)=\left(1-\frac{\Lambda'(1)}{P'(1)}\right)\log 2=R_{\mathrm{des}}\log 2. \tag{11.26}$$

大多数实际关心的情形中，[8]ϕ 在 $\omega=1/2$ 取最大值，如图 11.2、11.3、11.4。此时式 (11.26) 表明码率等于设计码率：

命题 11.2. *设 R 为 $\mathrm{LDPC}_N(\Lambda,P)$ 中码的码率，设计码率 $R_{\mathrm{des}}=1-\Lambda'(1)/P'(1)$，$\phi$ 由式 (11.17) 至 (11.19) 定义。若 ϕ 在 $[0,1]$ 上的绝对最大值于 $\omega=1/2$ 取得，则对任意 $\delta>0$，存在与 N 无关的正常数 $C_1(\delta)$，使*

$$\mathbb{P}\{|R-R_{\mathrm{des}}|\geq\delta\}\leq C_1(\delta)2^{-N\delta/2}. \tag{11.27}$$

[7]译注：最小距离的端点通常应按任意固定 $\omega<\omega_*$ 的渐近下界理解；这里的无码字与不改变码率都不是逐个有限块长的无条件断言。

[8]也有例外，参考文献见章末注释。

证明. 已知 $R \geq R_{\mathrm{des}}$，只需证明上界。设码字总数为 $\mathcal{N}$，则 $R = (\log_2 \mathcal{N})/N$。Markov 不等式给出

$$\begin{aligned}\mathbb{P}\{R \geq R_{\mathrm{des}} + \delta\} &= \mathbb{P}\{\mathcal{N} \geq 2^{N(R_{\mathrm{des}}+\delta)}\} \\ &\leq 2^{-N(R_{\mathrm{des}}+\delta)}\mathbb{E}\mathcal{N}. \end{aligned} \tag{11.28}$$

平均权重枚举为 $\mathbb{E}\mathcal{N}(w) \doteq \exp\{N\phi(w/N)\}$，可能的 w 只有 $N+1$ 个，因此

$$\mathbb{E}\mathcal{N} \doteq \exp\left\{N \sup_{\omega\in[0,1]} \phi(\omega)\right\}. \tag{11.29}$$

按假设，上确界为 $R_{\mathrm{des}}\log 2$，故存在 $C_1(\delta)$，使任意 N 都满足 $\mathbb{E}\mathcal{N} \leq C_1(\delta)2^{N(R_{\mathrm{des}}+\delta/2)}$。代回式 (11.28) 得

$$\mathbb{P}\{R \geq R_{\mathrm{des}} + \delta\} \leq C_1(\delta)2^{N\delta/2}. \tag{11.30}$$

□

译注： 最后一式按源文保留了正指数。由前两步相乘，应为 $2^{-N\delta/2}$，与命题一致。将逐点指数渐近用于随 N 变化的全部权重求和，还需相应的一致估计；此处沿原证明概述，不补称已给完整细节。

11.3 LDPC 码在二元对称信道上的容量

权重枚举研究表明，$l_{\min} \geq 3$ 的 LDPC 系综具有良好的短距离性质。若发送码字的广延距离 $N\omega_*$ 内没有其他码字，则任何改变少于 $\omega_*/2$ 比例比特的错误都可纠正，即使错误由对抗性信道引入。这里研究给定概率信道引入的典型错误，专注于独立以概率 $p < 1/2$ 翻转各比特的 BSC(p)。照常假设发送全零码字 $x^{(0)} = 0$，收到 $y = (y_1, \ldots, y_N)$，其分量独立同分布，以概率 $1-p$ 取 0、概率 p 取 1。使块错误率最小的码字 MAP 解码，[9]输出与 y 最近的码字。我们暂不考虑其实现及复杂度。

码 $\mathcal{C}$ 的块错误概率 $P_{\mathrm{B}}(\mathcal{C})$，是存在不同于 0 的“错误”码字、其到 y 的距离小于 $d(0,y)$ 的概率。系综平均 $P_{\mathrm{B}} = \mathbb{E}P_{\mathrm{B}}(\mathcal{C})$ 是性能的重要指标。我们将说明，大 N 下 $l_{\min} \geq 3$ 的码有一个相变：低噪声 $p < p_{\mathrm{ML}}$ 时 P_{B} 的极限为零，高噪声 $p > p_{\mathrm{ML}}$ 时则不为零。p_{ML} 的计算留到第“??”章，这里推导若干严格界，表明某些 LDPC 码的 ML 解码性能很接近 Shannon 界。[10]

11.3.1 下界

先给出对任意线性码都成立的 BSC 块错误概率界。令码本大小为 $\mathcal{N} = 2^{NR}$。由并集界，

$$\begin{aligned}P_{\mathrm{B}}(\mathcal{C}) &= \mathbb{P}\{\exists \alpha \neq 0 :\ d(x^{(\alpha)}, y) \leq d(0,y)\} \\ &\leq \sum_{\alpha=1}^{\mathcal{N}-1} \mathbb{P}\{d(x^{(\alpha)}, y) \leq d(0,y)\}. \end{aligned} \tag{11.31}$$

[9]所有码字先验等概率，因此它与最大似然解码一致。

[10]译注：原文先以相变描述引入阈值，后文明确说高噪声侧极限的一般存在性尚无证明。前述概括不能理解为本章证明了所有系综的完整相变。距离相等时的判决规则也需指定；以下把平局计入错误事件，给出实际块错误概率的上界。

由于 y_i 为独立同分布 Bernoulli 变量，右侧概率只通过权重依赖 $x^{(\alpha)}$。记前 w 位为 1、其余为 0 的向量为 $x(w)$，码的权重枚举函数为 $\mathcal{N}(w)$，则

$$P_{\mathrm{B}}(\mathcal{C}) \le \sum_{w=1}^{N} \mathcal{N}(w)\mathbb{P}\{d(x(w),y) \le d(0,y)\}. \tag{11.32}$$

概率可写为 $\sum_u \binom{w}{u} p^u(1-p)^{w-u}\mathbb{I}(u \ge w/2)$，其中 u 是前 w 个分量中 $y_i = 1$ 的数目。标准 Chernoff 估计给出好用的界：对任意 $\lambda > 0$，

$$\mathbb{P}\{d(x(w),y) \le d(0,y)\} \le \mathbb{E}e^{\lambda[d(0,y)-d(x(w),y)]} = [(1-p)e^{-\lambda} + pe^{\lambda}]^w.$$

最优选择为 $\lambda = \frac{1}{2}\log[(1-p)/p] > 0$，于是

$$P_{\mathrm{B}}(\mathcal{C}) \le \sum_{w=1}^{N} \mathcal{N}(w)e^{-\gamma w}, \tag{11.33}$$

其中 $\gamma \equiv -\log\sqrt{4p(1-p)} \ge 0$。量 $\sqrt{4p(1-p)}$ 有时称为 Bhattacharya 参数。[11]

习题 11.5. *考虑一般二元无记忆对称信道，转移概率为 $Q(y|x)$，$x \in \{0,1\}$、$y \in \mathcal{Y} \subseteq \mathbb{R}$。先证明，将 Hamming 距离替换为原文所称的对数似然*

$$d_Q(x|y) = -\sum_{i=1}^{N} \log Q(y_i|x_i), \tag{11.34}$$

式 (11.31) 仍成立。提示：回忆式 (6.3)、(6.4) 中给定接收消息 y 时发送码字为 x 的概率 $P(x|y)$ 的一般表达。随后重复式 (11.31) 至 (11.33) 的推导。最终 $\gamma = -\log B_Q$，其中 $B_Q = \sum_y \sqrt{Q(y|1)Q(y|0)}$ 为 Bhattacharya 参数。

译注： 式 (11.34) 实为负对数似然；原名称照录。连续输出时，Q 须解释为密度，相应求和改为积分。

式 (11.33) 展示了两个因素：权重枚举函数，以及依赖信道的 $e^{-\gamma w}$。权重越大，其贡献越被指数压低，因为接收消息更接近大权重码字而不是全零码字的概率更小。

以上对任意给定码有效。现在对 LDPC 系综取平均，直接得到

$$\begin{aligned} P_{\mathrm{B}} \equiv \mathbb{E}_{\mathcal{C}} P_{\mathrm{B}}(\mathcal{C}) &\le \sum_{w=1}^{N} \overline{\mathcal{N}}(w)e^{-\gamma w} \\ &\doteq \exp\left\{ N \sup_{\omega\in(0,1]} [\phi(\omega) - \gamma\omega] \right\}. \end{aligned} \tag{11.35}$$

单独看这个式子并无用处，因为上确界不小于 $\omega = 0$ 处的值，原文称它为正。不过 $l_{\min} \ge 3$ 时，大 N 下以趋于 1 的概率，在 $(0,\omega_*)$ 内不存在错误码字。因此可将极大化区间改为 $[\omega_*, 1]$。原文说明，由 Markov 不等式，只要 $N\sum_{w=1}^{N\omega_*-1}\overline{\mathcal{N}}(w) \to 0$，便可证明这一点。若 $\sup_{\omega\in[\omega_*,1]}[\phi(\omega)-\gamma\omega] < 0$，该界有用，$P_{\mathrm{B}} \to 0$。于是得到：[12]

[11] 译注：该人名在通行拼法中常写 Bhattacharyya；这里保留原文名称。$p = 0$ 时公式按极限理解。

[12] 译注：未限制区间的上确界只能据所述理由断言非负，不必严格为正。删除小权重区时，需将含此类码字的坏码概率单独控制，不能将对典型码的限制直接当作全部系综的精确平均恒等式；原文给出的带额外 N 的条件是充分条件。

命题 11.3. *考虑 $l_{\min} \geq 3$ 的 $\mathrm{LDPC}_N(\Lambda, P)$ 中随机码用于 $\mathrm{BSC}(p)$、$p < 1/2$ 时的平均块错误率 P_{B}。令 $\gamma = -\log\sqrt{4p(1-p)}$，$\phi$ 为式 (11.4) 定义的权重枚举指数，可由式 (11.17) 至 (11.19) 计算。若对每个满足 $\phi(\omega) \geq 0$ 的 $\omega \in (0,1]$ 均有 $\phi(\omega) < \gamma\omega$，则大块长极限下 $P_{\mathrm{B}} \to 0$。*

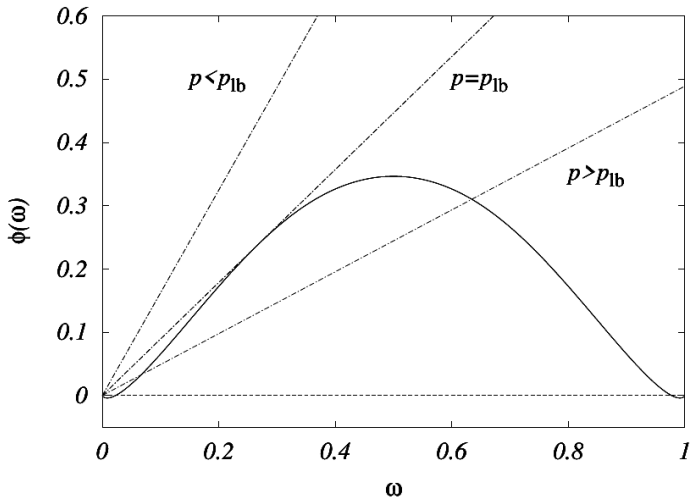


图 11.5: $\mathrm{LDPC}_N(3,6)$ 用于二元对称信道时，可靠通信阈值下界的几何构造。此处 $p_{\mathrm{LB}} \approx 0.0438737$；另两条线为 $p = 0.01 < p_{\mathrm{LB}}$ 和 $p = 0.10 > p_{\mathrm{LB}}$。取自 Part C PDF 第 63 页 (原 231)。

这一结果有直观的几何解释，如图 11.5 的 $(3,6)$ 例子。p 从 0 增加到 $1/2$ 时，γ 从 $+\infty$ 降到 0。条件 $\phi(\omega) < \gamma\omega$ 表示曲线位于过原点、斜率为 γ 的直线之下。记直线首次接触曲线时的最小 p 为 p_{LB}。

几何构造给出 $p_{\mathrm{LB}} > 0$。另一方面，对任意非零码率 $R > 0$，Shannon 定理表明足够大的 p 下 P_{B} 与零保持距离。ML 阈值 p_{ML} 可定义为使 $\lim_{N\to\infty} P_{\mathrm{B}} = 0$ 的最大 p，更准确地说，是其上确界。实际含义是：对任意 $p < p_{\mathrm{ML}}$，只要块长足够大，就能用系综中的码以任意小错误概率通信。命题 11.3 因而给出

$$p_{\mathrm{ML}} \geq p_{\mathrm{LB}}. \tag{11.36}$$

一般预期 $p > p_{\mathrm{ML}}$ 时 P_{B} 的极限存在且严格为正，但原文明确说这一陈述尚无证明。

在 $p = p_{\mathrm{LB}}$ 处，错误率上界由权重 $w \approx N\widetilde{\omega}$ 的码字主导，其中 $\widetilde{\omega} > \omega_*$ 是 $\phi(\omega) - \gamma\omega$ 取最大值的位置。这提示，每次发生错误时，都会有有限比例比特解码错误，且此比例在不同传输及不同码之间涨落不大。几何构造还提示一个不太明显、但基本正确的猜测：穿过 p_{ML} 时，该比例从 0 不连续跳到有限值。[13]

习题 11.6. *研究 $l_{\min} = 2$ 的情形。命题 11.3 不再适用，但仍可用式 (11.35)。*

(i) 考虑图 11.3 的 $(2,4)$ 系综，小权重行为见式 (11.24)。足够小 p 下，合理假设块错误率由小权重码字主导。在此假设下用式 (11.35) 估计 P_{B}。

[13]译注：这里沿用作者的启发式解释；并集上界的主导权重本身并不证明真实错误事件的条件分布或跃变。

(ii) 证明 $p \geq p_{\mathrm{loc}}$ 时此假设失效，其中 $p_{\mathrm{loc}} \leq 1/2$ 满足 $3\sqrt{4p(1-p)} = 1$。

(iii) 讨论一般 $l_{\min} = 2$ 且 ϕ 在 $[0,1]$ 上为凹函数的码系综。

(iv) 画出一种权重枚举指数，使小权重码字主导假设在到达 p_{loc} 前就失效。

(v) $p < p_{\mathrm{loc}}$ 与 $p > p_{\mathrm{loc}}$ 时，预期平均比特错误率 P_{b} 怎样？

习题 11.7. 讨论 $l_{\min} = 1$ 时块错误率的定性行为。

11.3.2 上界

仍考虑 BSC，为简单起见限于正则 (l,k) 码。Gallager 证明了下述上界。

定理 11.4. 令 p_{ML} 为使用 $\mathrm{LDPC}_N(l,k)$ 中的码在二元对称信道上可靠通信的阈值，设计码率 $R_{\mathrm{des}} = 1 - k/l$。则 $p_{\mathrm{ML}} \leq p_{\mathrm{UB}}$，其中 $p_{\mathrm{UB}} \leq 1/2$ 为下式的解：

$$\mathcal{H}(p) = (1 - R_{\mathrm{des}})\mathcal{H}\left(\frac{1-(1-2p)^k}{2}\right). \tag{11.37}$$

译注： 定理将设计码率写为 $1-k/l$，与本章前面及表格的 $1-l/k$ 相反，按源保留。该方程还有平凡解 $p=0$，表中阈值指适用条件下的非平凡正解。下述 $2^{N\mathcal{H}(p)}$ 使用比特熵；原稿同一 $\mathcal{H}$ 记号在自然指数和以 2 为底的计数中混用，数值计算需相应换底。

这里不作完整证明，而给出可进一步严格化的一系列启发式论证，细节见原始文献。假设发送全零码字并收到含噪声的 y。接收端寻找距 y 约 Np 且满足所有校验的 x。记伴随式 $z = Hx \in \{0,1\}^M$，乘法按模 2。它有 M 个分量；若 x 为码字，则所有校验满足，$z = 0$。至少有一个向量满足 $d(x,y) \approx Np$、$z = 0$，即发送码字 0。只有它是唯一这样的向量时，解码才成功。

距 y 约 Np 的向量数约为 $2^{N\mathcal{H}(p)}$。估计这些向量对应的不同伴随式数：写 $x = y \oplus x'$，问题等价于计算权重约 Np 的 x' 所产生的 $z' = Hx'$ 的数目。将 x' 看成均值为 p 的 N 个独立 Bernoulli 变量，便只需统计不同的典型 z'。由于码是正则的，每个 z'_i 都是参数为

$$p_k = \sum_{\substack{n=1 \\ n\text{为奇数}}}^{k} \binom{k}{n} p^n (1-p)^{k-n} = \frac{1-(1-2p)^k}{2} \tag{11.38}$$

的 Bernoulli 变量。若 z' 各比特独立，则典型向量数为 $2^{N(1-R_{\mathrm{des}})\mathcal{H}(p_k)}$，因为维数 $M = N(1-R_{\mathrm{des}})$。比特间关联会减少这个数，故独立估计给出上界。

再假定集合中每个 z 的原像数，即满足 $Hx = z$ 的 x 数，近似相同。若

$$2^{N\mathcal{H}(p)} \gg 2^{N(1-R_{\mathrm{des}})\mathcal{H}(p_k)},$$

则每个 z 都有指数多个原像，特别是 $z = 0$，故不能唯一解码。相反情形中，大多数 z 至多对应一个 x，$z = 0$ 也如此，解码就可能成功。[14]

[14] 译注：此处对典型集、关联与近似等原像数的推论保持启发式强度，没有在本文中补成完整证明。

11.3.3 界的总结

表 11.1: 正则 LDPC 系综在 BSC 上可靠通信阈值的界。第 3 列为设计码率，第 4、5 列分别为命题 11.3 的下界和定理 11.4 的上界，第 6 列为 Gallager 改进下界，最后一列为 Shannon 极限。原表数据照录。

l	k	R_{des}	本节下界	Gallager 上界	Gallager 下界	Shannon 极限
3	4	1/4	0.1333161	0.2109164	0.2050273	0.2145018
3	5	2/5	0.0704762	0.1397479	0.1298318	0.1461024
3	6	1/2	0.0438737	0.1024544	0.0914755	0.1100279
4	6	1/3	0.1642459	0.1726268	0.1709876	0.1739524
5	10	1/2	0.0448857	0.1091612	0.1081884	0.1100279

译注： 表中 $(4,6)$ 行的直接下界 0.1642459，与式 (11.10) 及切线构造不符。对同一参数式作有界数值极大化，得到 $p_{\mathrm{LB}} \approx 0.0952280$；其余四行的直接下界均复现至约 10^{-7}。原表数字保留，数值证据另存，未把该检查当作严格误差认证。表 11.1 对若干正则 LDPC 系综给出了 p_{ML} 的可能区间。多数情况下，直接上下界相差仍大，与容量相差约一倍。Gallager 通过细化前述论证给出的改进下界大大减小了不确定性。不过，后面会看到这两种界都不紧。特别在 k, l 增大时，这些码很接近 Shannon 极限。

习题 11.8. 令 p_{Sh} 为 *Shannon* 信道编码定理给出的 p_{ML} 上界，即 $\mathcal{H}(p) = 1 - R$ 的 $p_{\mathrm{Sh}} \le 1/2$ 解。证明若 $R = R_{\mathrm{des}}$，正如正则 *LDPC* 系综以高概率满足的那样，则 $p_{\mathrm{UB}} < p_{\mathrm{Sh}}$。

11.4 一种简单解码器：比特翻转

目前分析的是最优 ML 解码下 LDPC 系综的行为，但没有已知的快速算法实现这一解码。朴素方法扫描所有 $x^{(\alpha)}$，$\alpha = 0, \dots, 2^{NR} - 1$，选出似然 $Q(y|x^{(\alpha)})$ 最大者；码字先验等概率时，这就是码字 MAP。时间随块长指数增长，在错误率接近最优的大 N 区域并不实用。

LDPC 码的意义在于存在快速的次优解码算法，性能接近理论最优，因此也接近 Shannon 极限。这里介绍极简单的比特翻转算法。接收到消息 y 后，按下列过程寻找发送码字 x：

比特翻转解码器

0. 令 $x(0) = y$。

1. 寻找一个比特，使其所属的不满足校验数多于满足校验数。

2. 若存在这种比特，则翻转它：$x_i(t{+}1) = x_i(t) \oplus 1$。其余比特不变：对 $j \neq i$，$x_j(t{+}1) = x_j(t)$。若不存在，则返回 $x(t)$ 并停止。

3. 重复步骤 2 和 3。

译注： 最后一步按原文写 “重复步骤 2 和 3”，但编号 2 为执行翻转，3 为此重复指令。按算法意图应回到寻找可翻转比特的步骤 1；这里不静默修改原伪代码。

通常在满足步骤 1 条件的比特中均匀随机选择，不过以下分析与此无关。

习题 11.9. 考虑正则 (l,k) *LDPC* 系综中的码，$l \geq 3$。假设接收消息仅有一个位置不同于发送消息，证明比特翻转算法总能纠正这样的错误。

译注： 原习题的“总能”缺少图结构或选择条件。反例是一个 3×6 的全 1 校验矩阵，属于 $(3,6)$ 正则图；发送全零、仅第 1 位错时，所有 6 个比特都邻接 3 个不满足校验。若翻转另一位，就得到权重 2 的非零码字，算法停止且解码错误。不能将对典型随机局部结构的结论当作对每个正则码的保证。

习题 11.10. 假设信道引入两个错误。画出一个正则 (l,k) 码的因子图，使比特翻转算法无法纠正此错误事件。这样的图在系综中的概率如何？

为监测算法，定义“能量”

$$E(t) \equiv x(t) \text{ 所不满足的奇偶校验方程数.} \tag{11.39}$$

它是非负整数，$E(t)=0$ 时算法停止，输出 $x(t)$。此外 $E(t)\leq M$，且每个循环至少下降 1。因此算法复杂度为 $O(N)$，这通常被视为许多通信问题的最终目标。[15]

算法输出是否与发送码字相关仍需研究。图 11.6 展示了一个数值实验：对 $(5,10)$ 正则系综，在一组离散噪声值上，每点生成约 1000 组随机码与信道实现，再运行上述算法，绘出成功解码块的比例及残余能量 $E_* = E(t_*)$，其中 t_* 为总迭代次数。数据提示比特翻转可克服有限噪声：当信道损坏少于约 2.5% 比特时，以高概率恢复原消息。系统越大，块错误率曲线越陡。自然猜想，渐近上在明确的 $p_{\rm bf}$ 发生相变：$p<p_{\rm bf}$ 时 $P_{\rm B}^{\rm bf}\to 0$，$p>p_{\rm bf}$ 时趋 1，数值上 $p_{\rm bf}=0.025\pm 0.005$。

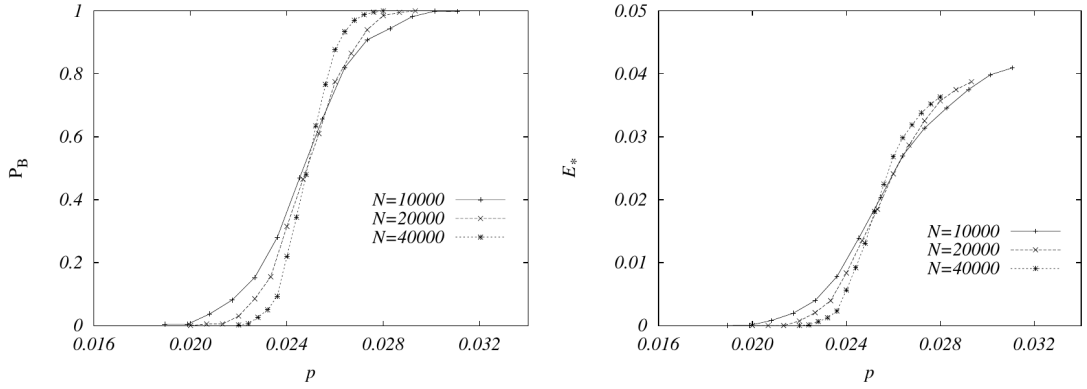


图 11.6: 随机 $(5,10)$ 正则 LDPC 码在二元对称信道上的比特翻转解码性能。左：块错误率。右：停止时未满足校验的残余数量；原图纵轴标 E_*，数值尺度见译注。统计误差条小于符号。原图注将 BSC 误排为 BCS。取自 Part C PDF 第 66 页（原 234）。

译注： 正文说绘成功比例，而左图及其图注为块错误率。右图纵轴小于 0.05，不能是每次运行整数校验数的直接典型尺度；原文没有注明是否除以 N 或 M。保留图与原定义，未自行指定归一化。

[15]译注：能量下降直接控制的是翻转次数。总运行时间为线性还需固定有界度，并维护可翻转节点及局部校验更新；若每轮从头扫描全部比特，不由此推出线性时间。

表 11.1 给出 $(5,10)$ 码的 $0.108188 \le p_{\mathrm{ML}} \le 0.109161$。比特翻转明显次优，但考虑到极端简单，性能仍令人惊讶。

能否给出性能保证？一种方法利用因子图的*扩展性质*。若正则 (l,k) 图的任意变量节点集 U 在 $|U| \le N\varepsilon$ 时，其相邻校验节点集 D 都满足 $|D| \ge \delta|U|$，则称图为 (ε,δ) *扩展图*。粗略地说，较大的扩展常数 δ 使任意小组错误比特产生大量不满足校验，算法可据此纠错。

随机图是很好的扩展图。直观理由如下：对固定小集 U，它及相邻函数节点 D 诱导的子图以高概率为树，初等计数便得 $|D| = (l-1)|U| + 1$。这提示足够小 ε 下可达到接近 $l-1$ 的扩展因子。不过论证有若干缺陷。首先，U 诱导的子图只有在 U 为次线性大小时才是树，而我们关心对某个固定 N 的所有 $|U| \le \varepsilon N$ 子集。其次，多数小集为树并不保证所有小集都扩展良好。尽管如此，可以证明该启发式扩展因子基本正确。[16]

命题 11.5. *设 $\mathcal{F}$ 为 (l,k) 系综中的随机因子图。对任意 $\delta < l-1$，存在常数 $\varepsilon = \varepsilon(\delta;l,k) > 0$，使 $N \to \infty$ 时图以趋于 1 的概率为 (ε,δ) 扩展图。*

特别地，$l \ge 5$ 时，随机正则因子图以高概率为 $(\varepsilon, 3l/4)$ 扩展图。这已足以保证低噪声下的良好性能。

定理 11.6. *考虑正则 (l,k) LDPC 码 $\mathcal{C}$，假设其因子图为 $(\varepsilon,3l/4)$ 扩展图。则比特翻转算法能纠正二元对称信道产生的任何少于 $N\varepsilon/2$ 个错误的模式。特别地，$p < \varepsilon/2$ 时，在 $\mathrm{BSC}(p)$ 上有 $P_{\mathrm{B}}(\mathcal{C}) \to 0$。*

证明. 照常假设输入为全零码字。记当前构型 $x(t)$ 的权重为 $w = w(t)$，不满足校验数为 $E = E(t)$，并记与至少一个错误比特邻接的满足校验数为 F；比特取 1 即为错误。

先假设某时刻 $0 < w(t) \le N\varepsilon$。扩展性质给出 $E + F > 3lw/4$。每个不满足校验至少连接一个错误比特，而邻接错误比特的满足校验至少连接两个，因此 $E + 2F \le lw$。消去 F 得 $E(t) > lw(t)/2$。令 $E_i(t)$ 为包含比特 x_i 的不满足校验数，则

$$\sum_{i:x_i(t)=1} E_i(t) \ge E(t) > \frac{1}{2} lw(t). \tag{11.40}$$

故至少有一个比特的不满足邻居多于满足邻居，算法不会停止。

现在以 $w(0) \le N\varepsilon/2$ 启动。算法必在某个 t_* 停止，届时或者 $E(t_*) = w(t_*) = 0$、解码成功，或者 $w(t_*) \ge N\varepsilon$。后一情形中，每步权重只改变 1，故有 $w(t_*) = N\varepsilon$。上述不等式给出 $E(t_*) > Nl\varepsilon/2$，而 $E(0) \le lw(0) \le Nl\varepsilon/2$，与能量严格下降矛盾。因此算法最终达到 $w = E = 0$。 □

译注： 原定义给出 $|D| \ge 3l|U|/4$，证明却直接用了严格大于。对严格多数翻转规则，需要严格扩展余量，或另行处理等号，不能从非严格条件直接推出式 (11.40) 的严格号。随机图在 $l \ge 5$ 时可在 $3l/4 < \delta < l-1$ 选取余量。证明末段还将终止时刻与首次到达边界的时刻混同：逐步跨界只保证首次跨界时权重在边界附近，并不保证后来终止权重恰等于边界。应对首次跨界时刻作能量矛盾，并处理整数取整；原证明按源保留。

[16] 译注：原句“某个固定 N”与讨论 $N \to \infty$、固定正比例的语境不一致，应核查是否指固定 ε。此外，任意固定 U 的诱导子图通常可有多个分支；若为森林且有 c 个分支，计数是 $|D| = (l-1)|U| + c$。子线性大小本身也不足以对所有增长速率保证无环。此处保留原启发式，不将它用作命题证明。

基于扩展性质的方法指出了 LDPC 码表现良好的重要机制，即因子图的局部树状结构，并给出比特翻转临界噪声 $p_{\rm bf}$ 的显式下界。不过界相当悲观。例如 $(5,10)$ 系综已知在 $\varepsilon < \varepsilon_* \approx 10^{-12}$ 时典型图是 $(\varepsilon, 3l/4) = (\varepsilon, 15/4)$ 扩展图，而图 11.6 中数值模拟的有效噪声远大于 $\varepsilon_*/2$。

注释

现代的、Cook 定理之后的复杂性理论最初由 Berlekamp、McEliecee 和 van Tilborg (1978) 应用于编码，证明线性码的最大似然解码是 NP 困难的。[17]

LDPC 码由 Gallager 在博士论文中首次提出（Gallager, 1963; 1962），早于这些复杂性结论。早期结果的广泛介绍见 Gallager（1968），现代进展的详尽介绍见 Richardson 和 Urbanke (2006)。

Gallager 的建议当时未获足够关注。一种可能解释是 20 世纪 60 年代缺少模拟大码的计算能力。90 年代重新发现 LDPC 码（MacKay, 1999），至少部分源于 Turbo 码的发明（Berrou 和 Glavieux, 1996）。两类码很快被认作更大类 “图上的码” 的原型。

重新发现后最主要的技术进展，是引入非正则系综（Luby、Mitzenmacher、Shokrollahi、Spielman 和 Stemann, 1997; Luby、Mitzenmacher、Shokrollahi 和 Spielman, 1998）。不同系综在大块长极限下的 “等价性”，无论其确切意义如何，尚无形式证明。但第 “??” 章将看到，LDPC 分析最主要的性质是第 9.5.1 节的局部树状结构，这一性质对系综改变相当稳健。

Gallager (1963) 首先计算正则系综的平均权重枚举函数，并用于约束可靠通信阈值。一般情形由 Litsyn 和 Shevelev (2003)、Burshtein 和 Miller (2004)、Di、Richardson 和 Urbanke (2004) 研究。正则系综的平均与典型权重枚举函数在主导指数阶上一致，用统计物理术语说，退火与淬火计算一致。Di、Montanari 和 Urbanke (2004) 指出非正则系综并非如此。

命题 11.2 的实质自 Gallager (1963) 起已知，这里的表述来自 Méasson、Montanari 和 Urbanke (2005a)。该文还给出某些 “奇异” 系综，其平均权重枚举函数在 $w = N\omega_*$、$\omega_* \neq 1/2$ 取得最大值。

上界定理 11.4 的证明见 Gallager (1963)；较新改进见 Burshtein、Krivelevich、Litsyn 和 Miller (2002)。

比特翻转算法在 LDPC 码复兴中发挥重要作用，尤其是 Sipser 和 Spielman (1996) 的工作之后。这些作者关注基于扩展图的显式码构造，也给出了随机正则 LDPC 码的扩展界。第 11.4 节提到的扩展下界取自 Richardson 和 Urbanke (2006)。

[17] 译注：作者名 McEliecee 按草稿拼写保留，Part F 也用此拼写，不在此静默更名。

第十二章　自旋玻璃

第 2 章和第 8 章已经介绍过若干自旋玻璃的例子。和大多数平衡统计物理问题一样，它们可在因子图的一般框架下表述。自旋玻璃是无序系统，其磁性质由随机分布的杂质主导。理论旨在描述这种材料典型样品的行为，因此需要定义并研究自旋玻璃系综。

本章探讨这些模型的玻璃相。定义这一相及其独特性质并不容易，尤其难以仅用静态量描述。我们给出若干迄今有效的判据，并对精确可解的平均场模型中遇到的两种自旋玻璃转变加以分类。与这些可解情形相比，对现实模型的了解、尤其严格证明极少，甚至玻璃相的存在都尚未严格确立。[1]

先在第 12.1 节将 Ising 模型及其推广表为因子图，并引入几个系综。阻挫是自旋玻璃的关键特征，第 12.2 节结合规范变换讨论它，也说明如何仅用规范变换得到若干精确结果。第 12.3 节介绍玻璃相及其主要刻画方法；最后在第 12.4 节画出具有多个玻璃相的一个模型的相图。

12.1　自旋玻璃与因子图

12.1.1　广义 Ising 模型

回顾相互作用 Ising 自旋磁系统的基本成分。取 N 个值为 ± 1 的自旋 $\sigma = \{\sigma_1, \dots, \sigma_N\}$，其联合分布是能量

$$E(\sigma) = -\sum_{p=1}^{p_{\max}} \sum_{i_1 < \cdots < i_p} J_{i_1 \dots i_p} \sigma_{i_1} \cdots \sigma_{i_p} \tag{12.1}$$

对应的 Boltzmann 分布。指标 p 是相互作用阶数；单体项 $p = 1$ 也称外场相互作用，有时写为 $-B_i \sigma_i$。若对任意 $p \geq 2$、$i_1, \dots, i_p$ 都有 $J_{i_1 \dots i_p} \geq 0$，称模型为铁磁体；若均有 $J_{i_1 \dots i_p} \leq 0$，称反铁磁体；若 $p \geq 2$ 的耦合同时含正值与负值，则称自旋玻璃。

能量可重写为 $E(\sigma) = \sum_a E_a(\sigma_{\partial a})$，其中 $E_a(\sigma_{\partial a}) \equiv -J_a \sigma_{i_1^a} \cdots \sigma_{i_{p_a}^a}$。每个相互作用涉及大小为 p_a 的子集 $\sigma_{\partial a} = \{\sigma_{i_1^a}, \dots, \sigma_{i_{p_a}^a}\}$。在因子图中，相互作用用方形节点表示，自旋用圆形节点表示；若 σ_i 出现在 $\sigma_{\partial a}$ 中，则连边 $a - i$。图 9.7 已给过一个普通二维自旋玻璃的因子图，能量包含 $p = 1, 2$ 项。图 12.1 给出零磁场 SK 模型（仅有 $p = 2$）及 3 自旋模型的小样本。[2]

[1] 译注：有关“迄今”、“尚未证明”及后续数值结论均对应冻结作者草稿的写作时点；本译稿没有将其改写为当前研究进展综述。

[2] 译注：源文此处误将图号写为 12.1.1；对应的是实际图 12.1，这里链接该图。

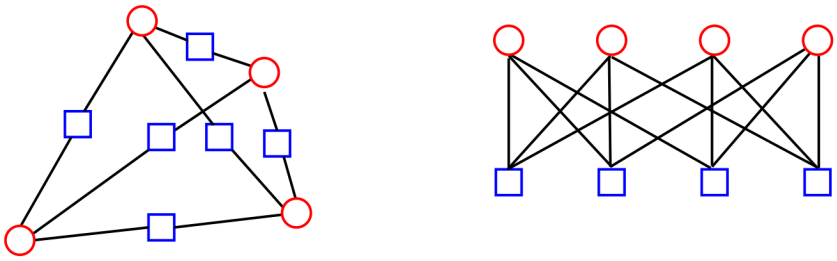


图 12.1: $N = 4$ 的 SK 模型（左）及全连接 3 自旋模型（右）的因子图。方形表示自旋间的相互作用。取自 Part C PDF 第 72 页（原 240）。

式 (12.1) 可直接解释为磁系统。此前的语言来自这一应用：自旋是磁粒子的“转动”自由度，其平均为磁化强度等。在这种背景下，不同自由度最主要的相互作用为两体项 $-J_{ij}\sigma_i\sigma_j$。

高阶项在其他应用中自然出现，一个简单例子是格点粒子系统，用于模拟液气、液固等相变。通常从有 N 个顶点的基础图 $\mathcal{G}$ 出发，常取 $\mathbb{Z}^d$ 的一部分；模拟真实物理系统时通常取 $d = 3$。每个顶点或者空置，或者被一个与其他粒子不可区分的粒子占据。粒子彼此不可区分，构型由占据变量 $n_i \in \{0, 1\}$ 刻画。能量 $E(n)$ 是 $n = \{n_1, \ldots, n_N\}$ 的函数，包含近邻粒子的局域相互作用。通过 $\sigma_i = 1 - 2n_i$，它通常可写成式 (12.1)，且 $p_{\max}$ 与 N 无关。下面习题给出几个例子。

习题 12.1. *考虑能与粒子库自由交换粒子的空盒子。除不能重叠外，粒子间没有相互作用。可取图为 $\mathbb{Z}^d$ 中边长 L 的立方体，规定每个粒子贡献能量 $-\mu$，即 $E(n) = -\mu \sum_i n_i$，这是通常所谓理想气体的一个模型。计算配分函数，用自旋变量重写能量并画因子图。*

习题 12.2. *在同一问题中，假设粒子在短距离相吸：每当相邻顶点 i, j 均被占据，系统获得能量 $-\epsilon$，这模拟液气相变。分别用 n_i 和 σ_i 写能量并画因子图。根据第 2.5 节的 Ising 相图讨论粒子系统。哪个物理量对应 Ising 模型的磁化强度？*

习题 12.3. *某些系统的分子无法在高密度下规则堆积，可能形成非晶固体。为模拟这种现象，可修改前述能量：每当一个粒子（被占据顶点）的近邻中有超过 k 个其他粒子，便增加惩罚能 $+\delta$。分别用 n_i 和 σ_i 写能量，并画因子图。*

12.1.2 自旋玻璃系综

一个自旋玻璃样品或实例由以下信息确定：

- 因子图，指定哪些自旋子集相互作用；
- 每个函数节点的耦合常数 $J_a \in \mathbb{R}$。

系综是样品空间上的概率分布。这里都假设耦合独立同分布，且独立于因子图。最常研究 Gaussian 耦合，或等概率取 ± 1 的耦合，后者称为 $\pm J$ 模型。一般记 J_a 的概率密度为 $\mathcal{P}(J)$。

物理学家关注两大家族：“现实”与“平均场”系综。前者着重模拟真实物理系统，后者则希望可以解析求解，从而为现实材料的行为提供线索。现实自旋玻璃为三维、某些情况下二维的系统。现实系综保留其几何结构：每个自旋关联一个 d 维位置，相互作用强度 $|J|$ 随距离迅速衰减。Edwards–Anderson 模型是原型，也是研究最多的例子之一：自旋位于 d 维超立方晶

格顶点，仅近邻之间有两体相互作用，即式 (12.1) 中 $p_{\max}=2$。因子图非随机，图 9.7 是 $d=2$ 的例子；唯一无序来自按 $\mathcal{P}(J)$ 抽取的随机 J_{ij}。通常还加均匀磁场，即非随机的 $p=1$ 项。对 $d\geq 2$ 的了解很有限，大多来自数值模拟；它们提示 $d\geq 3$ 有玻璃相，但尚无证明。

平均场模型没有一般的数学定义。基本上，它们是预期能通过优化某种关于 N 的大偏差率函数，精确得到 $N\to\infty$ 自由能密度的模型。允许这样求解的特点，是不具有有限维几何结构。

第 8.2 节的 p 自旋模型，特别是 $p=2$ 的 SK 模型，就是平均场模型。因子图仍非随机，无序仅来自耦合。它是正则二部图，含 $\binom{N}{p}$ 个函数节点，每个 p 元自旋组一个，故称*全连接*。函数节点度为 p，变量节点度为 $\binom{N-1}{p-1}$。度随 N 发散，耦合分布须适当随 N 缩放，参见式 (8.25)。

全连接模型在平均场家族中研究最充分，可用第 8 章的复本法，或后续章节的腔方法研究。两种启发式方法的一些预言已获严格证实。

每个自旋与发散多个其他自旋相互作用，是全连接模型不够现实的一面。为消除它，可研究有限平均度 Erdős–Rényi 随机图上的自旋玻璃：自旋关联顶点，两体相互作用关联边，耦合独立取自 $\mathcal{P}$。推广到 p 体也直接，称*稀释自旋玻璃*（DSG）。定义系综 $\mathrm{DSG}_N(p,M,\mathcal{P})$：

- 从 $\mathcal{G}_N(p,M)$ 生成因子图；
- 对每个连接 $i_1^a,\dots,i_p^a$ 的函数节点，从 $\mathcal{P}(J)$ 抽取耦合 $J_{i_1^a,\dots,i_p^a}$，引入

$$E_a(\sigma_{\partial a})=-J_{i_1^a,\dots,i_p^a}\sigma_{i_1^a}\cdots\sigma_{i_p^a};\tag{12.2}$$

- 最终能量为 $E(\sigma)=\sum_{a=1}^{M}E_a(\sigma_{\partial a})$。

固定 $\alpha=M/N$ 取 $N\to\infty$，便是热力学极限。

像随机图一样，可定义若干变体。在 $\mathrm{DSG}(p,\alpha,\mathcal{P})$ 中，因子图来自 $\mathcal{G}_N(p,\alpha)$：每个变量节点 p 元组独立以概率 $\alpha/\binom{N}{p}$ 接入函数节点。将会看到，固定边数和此变体在热力学极限下具有相同的每自旋自由能及若干其他热力学性质。原因之一，是随机节点任意有限邻域在两个系综中有相同的渐近分布。[3]

任意随机图系综都可按相同过程转成自旋玻璃系综，其中一些已有文献研究。沿用第 9 章记号，从 $\mathcal{D}_N(\Lambda,P)$ 得到的约束度分布一般稀释自旋玻璃记为 $\mathrm{DSG}_N(\Lambda,P,\mathcal{P})$。

稀释自旋玻璃与稀疏图码、随机可满足性等密切相关。我们对它们的理解介于全连接和现实模型之间。人们相信，复本和空腔法能精确计算其中大多数模型的许多热力学性质，但这些精确结果仍很少，只有部分得到严格证明。

12.2 自旋玻璃：约束与阻挫

零温自旋玻璃可以视为约束满足问题。例如考虑两体相互作用模型

$$E(\sigma)=-\sum_{(i,j)\in\mathcal{E}}J_{ij}\sigma_i\sigma_j,\tag{12.3}$$

[3]译注：原文再次漏掉连边概率分子的 N。若 $\alpha=M/N$ 固定，为匹配广延边数，应为 $N\alpha/\binom{N}{p}$；原概率只给平均 α 个函数节点，两个局部分布不能据此等同。这里保留原定义并指出与第 9 章相同的缩放冲突。

求和遍及图 $\mathcal{G}$ 的边集 $\mathcal{E}$；每条边对应因子图中的一个函数节点。零温时 Boltzmann 分布集中在能量最小的构型上。每条边诱导一个约束：$J_{ij}>0$ 时两自旋应同向，$J_{ij}<0$ 时应反向。若存在满足全部约束的构型，则基态能为 $E_{\rm gs}=-\sum_{(i,j)\in\mathcal{E}}|J_{ij}|$，称样品无阻挫，参见第 2.6 节；否则为有阻挫，其基态是违反尽可能少约束的构型。[4]

习题 12.4. 将图的一个“基本回路”(*plaquette*) 定义为无捷径的回路 $i_1,i_2,\dots,i_L,i_1$：对任意 $r,s\in\{1,\dots,L\}$，若 $r\neq s\pm1 \pmod L$，则图中不存在边 (i_r,i_s)。证明样品无阻挫当且仅当每个基本回路上的耦合乘积为正。

习题 12.5. 考虑式 (12.3) 的自旋玻璃，定义 *Boolean* 变量 $x_i=(1-\sigma_i)/2$。证明其约束满足问题可以变为一个 *2* 可满足性实例。提示：用 x_i,x_j 将约束 $J_{ij}\sigma_i\sigma_j>0$ 写成 *Boolean* 形式。

由于 2-SAT 属于 P，利用上一习题的等价性，可以在多项式时间内检查式 (12.3) 是否有阻挫。当 $p\geq3$ 时，这种方法不再高效，因为 $K\geq3$ 的 K-SAT 是 NP 完全的。不过第“??”章将说明，对任意 p，检查自旋玻璃能量是否有阻挫仍是多项式问题。[5]

12.2.1 规范变换

若样品虽有负耦合却无阻挫，实际上它是“伪装的铁磁体”：变换变量即可将其配分函数计算化为铁磁体的配分函数计算。根据假设，存在基态 σ^* 使所有边满足 $J_{ij}\sigma_i^*\sigma_j^*>0$。令 $\tau_i=\sigma_i\sigma_i^*\in\{\pm1\}$，便有 $E(\sigma)=E_*(\tau)\equiv-\sum_{(i,j)\in\mathcal{E}}|J_{ij}|\tau_i\tau_j$。这个铁磁系统与原系统的配分函数相同。

这类变量变换是规范变换的例子。一般变换同时改变全部自旋和耦合：

$$\sigma_i\mapsto\sigma_i^{(s)}=\sigma_i s_i,\qquad\qquad J_{ij}\mapsto J_{ij}^{(s)}=J_{ij}s_is_j,\tag{12.4}$$

其中 $s\in\{\pm1\}^N$ 任意。若将配分函数视为耦合 $J=\{J_{ij}:(ij)\in\mathcal{E}\}$ 的函数，

$$Z[J]=\sum_{\{\sigma_i\}}\exp\left\{\beta\sum_{(ij)\in\mathcal{E}}J_{ij}\sigma_i\sigma_j\right\},\tag{12.5}$$

$$Z[J]=Z[J^{(s)}].\tag{12.6}$$

耦合为 $J^{(s)}$ 的系统有时称为“规范变换后的系统”。

习题 12.6. 在式 (12.3) 中加入均匀磁场项 $-B\sum_i\sigma_i$，再作一般规范变换。为保持配分函数不变，均匀磁场应怎样改变？新磁场仍均匀吗？

习题 12.7. 将上述阻挫与规范变换的讨论推广到 $\pm J$ 三自旋玻璃，即式 (12.1) 中仅含 $p=3$ 项的模型。

---

[4]译注：末句按原文保留。一般不等模耦合的基态最小化违反约束的总权重 $\sum_{\rm violated}|J_{ij}|$，而非仅最小化个数；等模 $\pm J$ 情形两者一致。零耦合不施加约束，下文严格正号的判据应限于非零耦合边。

[5]译注：这是对每个相互作用都要求达到其单项最低能的可满足性检验；自旋乘积约束可化为模 2 线性方程。它不表示求有阻挫样品的基态同样容易。源文未完成的章引用保留。

12.2.2 Nishimori 温度...

许多自旋玻璃系综存在一个特殊的 *Nishimori* 温度，在此温度下，内能等一些热力学量可以精确计算。它对推断问题尤其有用，例如纠错码的符号 MAP 解码，因为这个温度在此类问题中自然出现。其推导有两条路线：应用规范变换（物理学中最初的发现途径），或将系统映射为推断问题。

先取第一种观点。为简单起见，考虑式 (12.3)，基础图 $\mathcal{G}=(\mathcal{V},\mathcal{E})$ 任意，各边耦合独立同分布，以概率 $1-p$ 取 $+1$，以概率 p 取 -1。$\mathbb{E}$ 表示对此分布的期望。Nishimori 温度为 $T_{\rm N}=1/\beta_{\rm N}$，其中 $\beta_{\rm N}=\frac{1}{2}\log[(1-p)/p]$。其选择使耦合分布满足

$$\mathcal{P}(J)=e^{-2\beta_{\rm N}J}\mathcal{P}(-J). \tag{12.7}$$

同一条件也可写成

$$\mathcal{P}(J)=\frac{e^{\beta_{\rm N}J}}{2\cosh(\beta_{\rm N}J)}Q(|J|), \tag{12.8}$$

$Q(|J|)$ 是耦合绝对值的分布；本例为 $|J|=1$ 处的 Dirac δ。**译注：** 式 (12.7) 的负号与原给 $\beta_{\rm N}$、概率及式 (12.8) 不相容；后式给出比值 $\mathcal{P}(J)/\mathcal{P}(-J)=e^{+2\beta_{\rm N}J}$。原式按源保留，后续计算实际使用后一分布。

现在计算平均内能[6] $U\equiv\mathbb{E}\langle E(\sigma)\rangle$。明确地，

$$U=\mathbb{E}\left\{\frac{1}{Z[J]}\sum_{\sigma}\left(-\sum_{(kl)}J_{kl}\sigma_k\sigma_l\right)e^{\beta\sum_{(ij)}J_{ij}\sigma_i\sigma_j}\right\}. \tag{12.9}$$

一般很难计算 U，但在 Nishimori 温度下，规范不变性使计算简化。写成 $U=\mathbb{E}\{Z_U[J]/Z[J]\}$，其中 $Z_U[J]=-\sum_{\sigma}\sum_{(kl)}J_{kl}\sigma_k\sigma_l\prod_{(ij)}e^{\beta_{\rm N}J_{ij}\sigma_i\sigma_j}$。任取 $s\in\{\pm1\}^N$，由式 (12.6) 的直接推广，$Z_U[J^{(s)}]=Z_U[J]$，因此

$$U=2^{-N}\sum_{s}\mathbb{E}\left\{\frac{Z_U[J^{(s)}]}{Z[J^{(s)}]}\right\}. \tag{12.10}$$

若 J_{ij} 独立服从式 (12.8)，则规范变换后的 $J'_{ij}=J^{(s)}_{ij}$ 仍独立，但分布变为

$$\mathcal{P}_s(J_{ij})=\frac{e^{\beta_{\rm N}J_{ij}s_is_j}}{2\cosh\beta_{\rm N}}. \tag{12.11}$$

于是 $U=2^{-N}\sum_s\mathbb{E}_s\{Z_U[J]/Z[J]\}$，$\mathbb{E}_s$ 对变换后的测度取期望。用 $\mathbb{E}_0$ 表示 $J_{ij}\in\{\pm1\}$ 上均匀测度的期望，得到

$$U=2^{-N}\sum_{s}\mathbb{E}_0\left\{\prod_{(ij)}\frac{e^{\beta_{\rm N}J_{ij}s_is_j}}{\cosh\beta_{\rm N}}\frac{Z_U[J]}{Z[J]}\right\} \tag{12.12}$$

$$=2^{-N}(\cosh\beta_{\rm N})^{-|\mathcal{E}|}\mathbb{E}_0\left\{\sum_{s}e^{\beta_{\rm N}\sum_{(ij)}J_{ij}s_is_j}\frac{Z_U[J]}{Z[J]}\right\} \tag{12.13}$$

$$=2^{-N}(\cosh\beta_{\rm N})^{-|\mathcal{E}|}\mathbb{E}_0\{Z_U[J]\}. \tag{12.14}$$

[6] 原注：第 2 章曾用同一符号 U 表示内能 $\langle E(\sigma)\rangle$ 本身，而非其平均；这里的用法应不会引起混淆。

容易算得 $\mathbb{E}_0 Z_U[J] = -2^N(\cosh\beta_{\mathrm{N}})^{|\mathcal{E}|-1}\sinh\beta_{\mathrm{N}}$，从而 Nishimori 温度下的平均能量为

$$U = -|\mathcal{E}|\tanh\beta_{\mathrm{N}}. \tag{12.15}$$

译注：原文紧接式 (12.14) 的 $\mathbb{E}_0 Z_U[J]$ 少了 $|\mathcal{E}|$ 因子。对每条边分别取均匀平均，可得

$$\mathbb{E}_0 Z_U[J] = -|\mathcal{E}|2^N(\cosh\beta_{\mathrm{N}})^{|\mathcal{E}|-1}\sinh\beta_{\mathrm{N}},$$

才能推出原文末式。正文表达式均按源保留。

这个结果对任意基础图成立，也可推广到满足式 (12.8) 的耦合分布，以及式 (12.1) 的多自旋模型。下面还给出更广的推广。

12.2.3 ...及其与概率的关系

上一节内能计算虽然直接，却有些神秘：究竟什么根本原因使 Nishimori 温度下的计算变简单？下面在稍抽象的框架下给出更一般的推导，说明它与推断的联系。

考虑如下过程：均匀随机选择构型 $\sigma \in \{\pm1\}$，其分布记为 $P_0(\sigma)$，再按条件分布抽取耦合 $J = \{J_a\}$：

$$P(J \mid \sigma) = e^{-\beta E_J(\sigma)} Q_0(J). \tag{12.16}$$

E_J 是耦合为 J 的能量函数，Q_0 是某个参考测度，可选得使 $P(J \mid \sigma)$ 归一化。它可解释为通信过程：信源均匀生成消息 σ，接收者观察耦合 J。[7]

联合分布为 $P(J,\sigma) = e^{-\beta E_J(\sigma)} Q_0(J) P_0(\sigma)$。用 Av 表示联合分布下的期望，以区别热平均及淬火平均。假设过程具有规范对称性，这在一般情形下定义 Nishimori 温度：任给 $s \in \{\pm1\}^N$，存在可逆映射 $J \mapsto J^{(s)}$，满足 $Q_0(J^{(s)}) = Q_0(J)$ 和 $E_{J^{(s)}}(\sigma^{(s)}) = E_J(\sigma)$。于是

$$P(\sigma^{(s)}, J^{(s)}) = P(\sigma, J), \qquad P(J^{(s)} \mid \sigma^{(s)}) = P(J \mid \sigma). \tag{12.17}$$

引入

$$\mathcal{U}(J) = \mathrm{Av}(E_J(\sigma) \mid J) = \sum_{\sigma} P(\sigma \mid J) E_J(\sigma), \tag{12.18}$$

并记 $U(\sigma_0) = \sum_J P(J \mid \sigma_0)\mathcal{U}(J)$。它就是能量为 E_J、耦合分布为 $P(J \mid \sigma_0)$ 的无序系统平均内能。例如取 σ_0 为全正构型、Q_0 正比于 $\{\pm1\}^{\mathcal{E}}$ 上均匀测度、E_J 如式 (12.3)，就得到上一节的 U。

规范不变性给出任意 s 下 $\mathcal{U}(J) = \mathcal{U}(J^{(s)})$，且 $U(\sigma_0)$ 不依赖 σ_0。因此可对 σ_0 平均来计算 U：

$$\begin{aligned} U &= \sum_{\sigma_0} P_0(\sigma_0) \sum_J P(J \mid \sigma_0) \sum_{\sigma} P(\sigma \mid J) E_J(\sigma) \\ &= \sum_{\sigma, J} P(\sigma, J) E_J(\sigma) = \sum_J P(J \mid \sigma_0) E_J(\sigma). \end{aligned} \tag{12.19}$$

[7]译注：原句构型域漏了幂 N；以下一直将 σ 作为 N 自旋构型使用。参考测度能同时对所有 σ 归一化是该构造的条件，并非任意能量都自动满足。

最后一步再次用了规范不变性。末式一般容易求值，因为 $P(J \mid \sigma_0)$ 下各 J_a 通常独立，特别是可直接重得式 (12.15)。**译注：**源末式中的 σ 未被求和且不受约束，按前述规范平均应将能量也取在同一固定参考构型，即 $E_J(\sigma_0)$。这里保留原式并说明其自由指标问题。连续耦合时上述和须理解为相应积分，可逆规范映射还须保持参考测度。

习题 12.8. *考虑任意图上的自旋玻璃，能量如式 (12.3)，耦合独立取自 $\mathcal{P}(J) = \mathcal{P}_0(|J|)e^{aJ}$。证明 Nishimori 逆温为 $\beta_{\mathrm{N}} = a$，该温度下内能为 $U = -|\mathcal{E}| \sum_J \mathcal{P}_0(|J|) J \sinh(\beta_{\mathrm{N}} J)$。若 $\mathcal{P}$ 是均值为 J_0 的 Gaussian 分布，证明 $U = -|\mathcal{E}|J_0$。*

12.3 什么是玻璃相？

12.3.1 自发局域磁化强度

物理学通过动力学性质定义“玻璃”。对这里的经典自旋模型，有若干物理上有意义的动力学。为明确起见，采用第 4.5 节的单自旋翻转 Glauber 动力学，但主要结论应不敏感于这一选择。设系统在零时处于平衡，即 $\sigma(0)$ 服从 Boltzmann 分布；$\langle\cdot\rangle_{\sigma(0)}$ 表示给定初态的动力学期望。在“固体”相中，[8]自旋在长时间尺度上仍与初值关联：

$$\lim_{t\to\infty} \lim_{N\to\infty} \langle \sigma_i(t) \rangle_{\sigma(0)} \equiv m_{i,\sigma(0)} \neq \langle \sigma_i \rangle. \tag{12.20}$$

换言之，在任意长但相对于系统大小有限的时间尺度上，系统趋于一个“准平衡态”，简称“准态”，其局域磁化强度依赖初态。

例如零场 $d \geq 2$ 的 Ising 铁磁体，在铁磁转变温度以下满足此条件：依初态不同，$m_{i,\sigma(0)} = M(\beta)$ 或 $-M(\beta)$，$M(\beta)$ 为自发磁化强度。两个准态均平移不变，彼此由简单对称变换联系。若各准态既不周期，也不由这种变换联系，便可称为玻璃相。

第“??”章将更详细讨论准态的动力学定义。不过，从平衡统计力学本身、不引入具体动力学来刻画玻璃相也很重要。对铁磁体，第 2 章已介绍解法。以 $\langle\cdot\rangle_B$ 表示在式 (12.1) 中加入均匀磁场后的 Boltzmann 平均，定义

$$m_{i,\pm} \equiv \lim_{B\to 0^{\pm}} \lim_{N\to\infty} \langle \sigma_i \rangle_B. \tag{12.21}$$

推广到玻璃的自然方法，是加入微弱非均匀场 $-\epsilon \sum_i s_i \sigma_i$，其中 $s \in \{\pm 1\}^N$ 任意。以 $\langle\cdot\rangle_{\epsilon,s}$ 记相应平均，令

$$m_{i,s} \equiv \lim_{\epsilon\to 0^{\pm}} \lim_{N\to\infty} \langle \sigma_i \rangle_{\epsilon,s}. \tag{12.22}$$

定义 *Edwards–Anderson 序参量*

$$q_{\mathrm{EA}} \equiv \lim_{\epsilon\to 0^{\pm}} \lim_{N\to\infty} \frac{1}{N} \sum_i \langle \sigma_i \rangle_{\epsilon,s}^2, \tag{12.23}$$

这里 s 为平衡构型；该量指示自旋玻璃相的出现。[9]

[8]原注：这一称呼来自固体中原子的优选位置不随时间变化，例如晶体中的位置为周期晶格的顶点。

[9]译注：以上 $0^{\pm}$ 按源保留，未假定两侧极限相等；序参量非零本身也不能排除前述铁磁有序，须结合其他判据。

仔细的读者会发现式 (12.20) 尚未完全定义：$N\to\infty$ 应怎样取？极限是否存在？结果怎样依赖 σ？这些微妙问题涉及无序系统纯态（极端 Gibbs 态）的恰当定义。尽管有许多研究，自旋玻璃纯态的定义仍未完全令人满意。

各种可操作的玻璃相定义，转而依靠比较系统的若干平衡构型，即从 Boltzmann 分布抽取的构型，再用其中一个确定极化场方向。这可能正是复本方法成功的主要思想。下面介绍基于此思想的两种判据，先讨论高温相的稳定性。

12.3.2 自旋玻璃磁化率

取能量如式 (12.1) 的样品，在位置 i 加局域场 B_i。自旋 j 对该场的磁化率为 $m_j=\langle\sigma_j\rangle_{B_i}$ 对 B_i 的变化率：

$$\chi_{ji}\equiv\left.\frac{dm_j}{dB_i}\right|_{B_i=0}=\beta\big(\langle\sigma_i\sigma_j\rangle-\langle\sigma_i\rangle\langle\sigma_j\rangle\big). \tag{12.24}$$

这里用了涨落耗散关系。第 2.5.1 节的均匀（铁磁）磁化率，描述平均磁化强度对无穷小均匀场的响应：$\chi=N^{-1}\sum_{i,j}\chi_{ji}$。在第 2.5 节的 Ising 铁磁相中，即零场且低于临界温度时，χ 随 N 发散。一种理解如下：以 $m(B)$ 表示无限体积的磁化强度，则铁磁相中

$$\chi=\lim_{B\to0}\frac{m(B)-m(-B)}{2B}=\lim_{B\to0^+}\frac{M}{B}=\infty. \tag{12.25}$$

这将磁化率发散与两个不同纯态（正态与负态）的存在联系起来。

什么磁化率适于探测自旋玻璃有序？应考虑微弱非均匀场 $B_i=s_i\epsilon$，局域磁化强度为

$$\langle\sigma_i\rangle_{\epsilon,s}=\langle\sigma_i\rangle_0+\epsilon\sum_j\chi_{ij}s_j+O(\epsilon^2). \tag{12.26}$$

受式 (12.25) 启发，比较沿 s,s' 两个方向扰动的结果：

$$\langle\sigma_i\rangle_{\epsilon,s}-\langle\sigma_i\rangle_{\epsilon,s'}=\epsilon\sum_j\chi_{ij}(s_j-s'_j)+O(\epsilon^2). \tag{12.27}$$

怎样选 s,s'？简单选择是独立均匀抽自 $\{\pm1\}^N$，以 $\mathbb{E}_s$ 表示该平均。上述差成为均值为零的随机变量，其二阶矩定义*自旋玻璃磁化率*，有时称*非线性磁化率*：

$$\chi_{\rm SG}\equiv\lim_{\epsilon\to0}\frac{1}{2N\epsilon^2}\sum_i\mathbb{E}_s\big(\langle\sigma_i\rangle_{\epsilon,s}-\langle\sigma_i\rangle_{\epsilon,s'}\big)^2. \tag{12.28}$$

这相当于自旋玻璃中的式 (12.25)。由式 (12.27)，$\chi_{\rm SG}=N^{-1}\sum_{ij}\chi_{ij}^2$，故

$$\chi_{\rm SG}=\frac{\beta^2}{N}\sum_{i,j}\big[\langle\sigma_i\sigma_j\rangle-\langle\sigma_i\rangle\langle\sigma_j\rangle\big]^2. \tag{12.29}$$

系统处于“正常”顺磁相的必要条件，是 $N\to\infty$ 时该量有限。[10]下面会看到，这一局域稳定性的必要条件并非总充分。

[10]原注：可以构造具有“奇异”顺磁相而自旋玻璃磁化率发散的模型，例如耦合分布的二阶矩无限；这里不考虑这些情形。

习题 12.9. 另一种自然选择，是将 s, s' 独立抽自 *Boltzmann* 分布。证明此时得到 $\chi_{\mathrm{SG}} = N^{-1}\sum_{i,j,k}\chi_{ij}\chi_{jk}\chi_{ki}$。文献尚未研究过这种磁化率，但可以合理预期它一般给出与式 (12.29) 相同的稳定性判据。

译注： 按式 (12.24) 的含 β 定义及 $\mathrm{Cov}(s_j, s_k) = \chi_{jk}/\beta$，上一习题右端应有额外 $1/\beta$。题目原式保留。

12.3.3 重叠分布函数$P(q)$

第 8.2.2 节定义过重叠分布，并讨论了具体例子；它是玻璃相的主要指标之一。对一般式 (12.1)，独立从 Boltzmann 分布抽取 σ, σ'，考虑 $q(\sigma,\sigma') = N^{-1}\sum_i \sigma_i\sigma'_i$。再对系综中的耦合和基础因子图随机取样，就得到重叠分布 $P(q)$。其矩为[11]

$$\int P(q)q^r\,dq = \mathbb{E}\left\{\frac{1}{N^r}\sum_{i_1,\dots,i_r}\langle\sigma_{i_1}\cdots\sigma_{i_r}\rangle^2\right\}. \tag{12.30}$$

特别地，一阶矩 $\int P(q)q\,dq = N^{-1}\sum_i m_i^2$ 是期望重叠，方差 $\mathrm{Var}(q) = \int P(q)q^2dq - [\int P(q)q\,dq]^2$ 与磁化率相关：

$$\mathrm{Var}(q) = \mathbb{E}\left\{\frac{1}{N^2}\sum_{i,j}\big[\langle\sigma_i\sigma_j\rangle - \langle\sigma_i\rangle\langle\sigma_j\rangle\big]^2\right\} = \frac{1}{N}\chi_{\mathrm{SG}}. \tag{12.31}$$

译注： 一阶矩若已平均无序，右端亦应含 $\mathbb{E}$。方差等式在一般非零局域磁化情况下不成立：由上一式，二阶矩是 $N^{-2}\sum_{ij}\mathbb{E}\langle\sigma_i\sigma_j\rangle^2$，减去均值平方并不等于连通关联平方之和。此外，按式 (12.29)，后者应对应 $\mathbb{E}\chi_{\mathrm{SG}}/(N\beta^2)$。零局域磁化且无序平均一致时，可消去前一问题，仍须保留 β^2。后文方差尺度的讨论需在适当条件下理解。

如何用 $P(q)$ 探测玻璃相？这里讨论平均场模型解所显示的特点。下一节会将重叠分布与第 12.3.1 节的扰动准态思想联系起来。一般地，[12]β 较小时系统处于顺磁相或液相，$P(q)$ 在 $N\to\infty$ 时集中于单一确定值 $q(\beta)$；两独立构型以高概率有此重叠。该相中 χ_{SG} 有限，因而 $P(q)$ 的方差按 $1/N$ 消失。

当 β 大于某个 β_c，$P(q)$ 可能出现结构，即极限中多个重叠值有非零概率。$T_c = 1/\beta_c$ 称为*静态或平衡玻璃转变温度*，$\beta > \beta_c$ 为平衡玻璃相。其渐近重叠分布通常有两类，对应复本方法中不同的对称性破缺方式。

1. *连续（完全复本对称性破缺，FRSB）玻璃转变*，见图 12.2。$\beta < \beta_c$ 的 δ 峰在 $\beta > \beta_c$ 时“展宽”为支集 $[q_0(\beta), q_1(\beta)]$ 上的分布，宽度在 $\beta\downarrow\beta_c$ 时连续趋零。分布在开区间内有严格正的连续密度，两端还有离散 δ 贡献。这种转变有先兆：先取 $N\to\infty$ 的磁化率在 $\beta\uparrow\beta_c$ 时发散，对实验、数值及解析识别临界温度很重要。

2. *非连续（1RSB）玻璃转变*，见图 12.3。玻璃相的渐近 $P(q)$ 也有非平凡结构，但情景不同：在 $\beta\le\beta_c$ 质量为 1 的 $q(\beta)$ 处 δ 峰，进入低温后成为 $q_0(\beta)$ 处质量 $1-x(\beta)<1$ 的峰，

[11] 原注：与第 8.2.2 节不同，这里 $P(q)$ 是有限 N 系统的重叠分布，而非其 $N\to\infty$ 极限。

[12] 原注：“一般地”应理解为“迄今研究的大多数感兴趣模型”，其中隐含若干假设，例如耦合分布有有限二阶矩。

同时在 $q_1(\beta) > q_0(\beta)$ 处出现质量 $x(\beta)$ 的第二峰。$\beta \downarrow \beta_c$ 时，$q_0(\beta) \to q(\beta_c)$，$x(\beta) \to 0$，但宽度不趋零，开区间 (q_0, q_1) 的概率在极限中为零。此时 χ_{SG} 在 $\beta \uparrow \beta_c$ 时有有限极限，没有“简单”先兆，下面会介绍更微妙的指标。

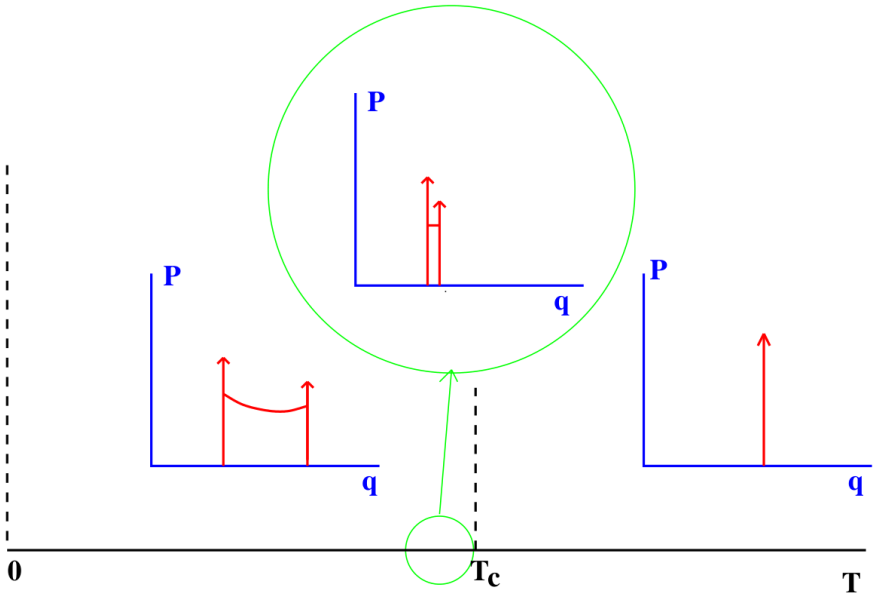


图 12.2: 连续 FRSB 玻璃转变处重叠分布序参量 $P(q)$ 的典型行为。竖箭头表示 Dirac δ 函数。取自 Part C PDF 第 84 页（原 252）。

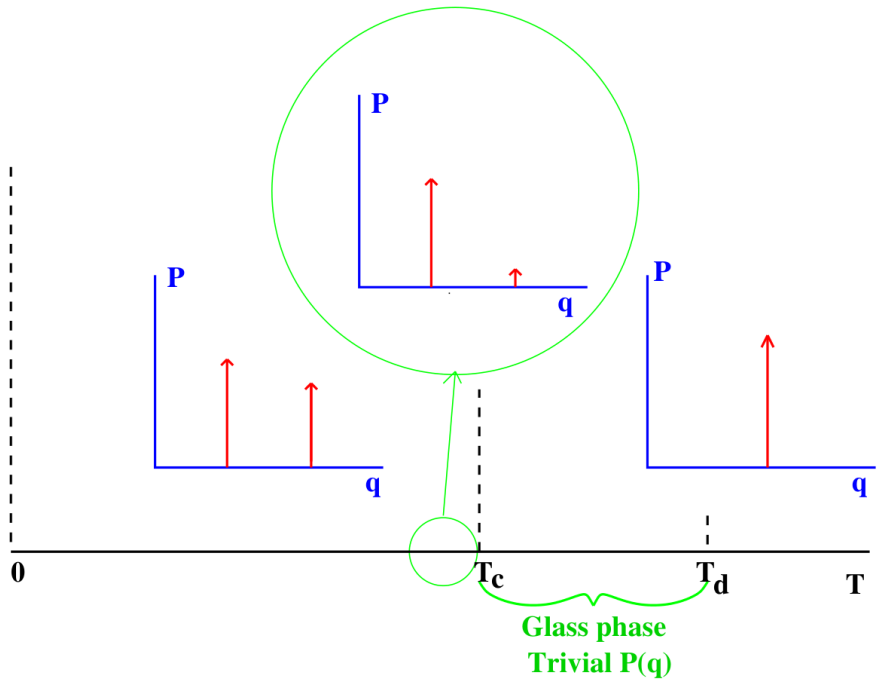


图 12.3: 非连续 1RSB 玻璃转变处 $P(q)$ 的典型行为。竖箭头表示 Dirac δ 函数。图中玻璃相而 $P(q)$ 平凡的区间为 $T_c < T < T_d$。取自 Part C PDF 第 85 页（原 253）。

非连续转变中的双峰结构有简单的几何解释。两独立 Boltzmann 构型的重叠，以高概率约为 q_0 或 q_1；Hamming 距离相应为 $N(1-q_1)/2$ 或 $N(1-q_0)/2$。这意味着测度 $p(\sigma)$ 集中在 Hamming 空间的一些区域，即簇。同簇两构型的典型距离约为 $N(1-q_1)/2$，异簇约为 $N(1-q_0)/2$。完整 Boltzmann 测度下重叠不依概率集中，限制于单簇后则集中。略形式化、但仍不精确地写成

$$p(\sigma) \approx \sum_{\alpha} W_\alpha p_\alpha(\sigma), \tag{12.32}$$

p_α 集中于单簇，W_α 为该簇的 Boltzmann 权重。按此解释，$x(\beta) = \mathbb{E}\sum_\alpha W_\alpha^2$。$\beta > \beta_c$ 时它为正，只有有限个簇的权重可观；若有 R 个等权簇，则 $x = 1/R$。这与 REM 及第 8.2 节全连接 p 自旋模型复本解的发现相同。[13]

一般在 T_c 以上某个温区，簇已经存在，测度却尚未凝聚于少数簇。探测这种中间区的簇，需要后面的工具。没有明确判据能预先判定转变类型。复本与腔方法的经验显示，$p = 2$ 的普通自旋玻璃及顶点覆盖等问题通常连续转变；结构玻璃、$p \geq 3$ 广义自旋玻璃、随机可满足性及着色通常非连续转变。同一系统在不同温度或其他参数下也可能发生两种转变，形成含多种玻璃相的丰富相图。

规范变换能否提供 $P(q)$ 的信息？遗憾的是，Nishimori 温度从不进入自旋玻璃相：该温度下的重叠分布集中于单值，下一习题给出提示。

习题 12.10. *利用第 12.2.1 节的规范变换，证明 Nishimori 温度下的 $P(q)$ 等于每自旋磁化强度 $m(\sigma) = N^{-1}\sum_i \sigma_i$ 的分布。许多模型中可预期这个磁化分布满足大偏差原理，并在 $N \to \infty$ 时集中于单值。*

译注： 分布恒等式与“集中于单值”需区分。后者不是规范对称性本身的无条件结论；例如零场自旋反演对称性、铁磁共存及临界条件须另行处理，不能仅凭大偏差原理保证唯一极小值。

12.3.4 从重叠分布到ϵ 耦合方法

重叠分布实际上与第 12.3.1 节的准态思想相关。再次用磁场 $-\epsilon\sum_i s_i\sigma_i$ 扰动 Boltzmann 分布，s 是一般构型，定义

$$E_{\epsilon,s}(\sigma) = E(\sigma) - \epsilon\sum_{i=1}^{N} s_i\sigma_i. \tag{12.33}$$

原能量与新加项都是广延量，即随 N 成比例增长，故在极限中扰动可能有显著作用。[14]扰动后的测度为

$$p_{\epsilon,s}(\sigma) = \frac{1}{Z_{\epsilon,s}} e^{-\beta E_{\epsilon,s}(\sigma)}. \tag{12.34}$$

用与 s 的平均距离度量扰动效果：

$$d(s,\epsilon) \equiv \frac{1}{N}\sum_{i=1}^{N} \frac{1}{2}\big(1 - s_i\langle\sigma_i\rangle_{s,\epsilon}\big). \tag{12.35}$$

[13]译注：“有限个权重可观”不要求总簇数有限，亦可有无限多个权重很小的簇；双重叠峰的几何解释依赖这里的聚簇图景。

[14]译注：耦合项的最大尺度为 $O(N)$，但对不相关随机构型其典型和可能仅为 $O(\sqrt{N})$；原文“两项都广延”应结合被扰动测度选择的构型理解。

因为 $\sum_i(1-s_i\sigma_i)/2$ 正是两构型不同的位置数。$\epsilon>0$ 为吸引耦合，$\epsilon<0$ 为排斥，容易证明 $d(s,\epsilon)$ 随 ϵ 递减。*

在 ϵ 耦合方法中，从未扰动的 Boltzmann 分布抽取随机 s，使其指向准态方向。对 s 和样品再平均，得到

$$d(\epsilon)\equiv\mathbb{E}\left\{\sum_s\frac{1}{Z}e^{-\beta E(s)}d(s,\epsilon)\right\}. \tag{12.36}$$

它与重叠分布计算有两点区别：其一，计算 $P(q)$ 时两个副本地位对等、独立且都服从 Boltzmann 分布；这里一个仍服从原分布，另一个服从依赖前者的扰动分布。其二，这里固定 ϵ 先取 $N\to\infty$，故原分布下指数不可能的重叠值，也可能主导式 (12.36)；它们在 $P(q)$ 的极限中权重为零。两种方法提供互补信息。

顺磁相中，$d(\epsilon)$ 的热力学极限仍为光滑函数，扰动没有剧烈影响；玻璃相中则出现奇异性。特别关心零处的不连续，定义

$$\Delta=\lim_{\epsilon\to0^+}\lim_{N\to\infty}d(\epsilon)-\lim_{\epsilon\to0^-}\lim_{N\to\infty}d(\epsilon). \tag{12.37}$$

必须先取 $N\to\infty$，有限 N 不可能不连续。预期 $\Delta\neq0$ 当且仅当处于 “固体” 相。可将加入正耦合再令其趋零看成物理制备过程：先迫使系统处于由 s 给出的能量有利构型，再缓慢撤去外力，看是否保留记忆（$\Delta>0$），还是 “液化”（$\Delta=0$）。**译注：** 按 d 递减及式 (12.37) 的顺序，$\Delta\le0$；记忆条件中的 $\Delta>0$ 与此符号约定相反。源定义与原叙述均保留，判据应关注非零跳跃的大小。

相较 $P(q)$，此方法有两项优点。

- 有时多个簇贡献测度，却有一个占主导，次主导簇的权重可能为 $W_\alpha=\exp[-\Theta(N^\theta)]$，$0<\theta<1$。此时 $P(q)$ 极限是单 δ 峰，不能与顺磁相区分，而 ϵ 耦合仍可通过零处的奇异性识别转变。

- 对非连续转变，可研究玻璃相中 $T>T_c$ 的区域。此时测度分散于指数多个簇，$P(q)$ 不能探测它们的存在，下一节讨论此情形。

12.3.5 1RSB 系统的聚簇相与势

1RSB 平衡玻璃相中，测度凝聚于少数构型簇。不过最引人注目的现象，是簇本身的出现。后面几章将说明，它对 Monte Carlo 动力学和其他算法有重要影响。Boltzmann 测度在另一个温度 $T_d>T_c$ 分裂为簇。$[T_c,T_d]$ 中称系统处于聚簇相，有时称动力学玻璃相；T_d 处称聚簇转变或动力学转变。这里有指数多个簇 $\mathcal{N}\doteq e^{N\Sigma}$，权重大致相等，增长率 Σ 称复杂度[15]或构型熵。

重叠分布的热力学极限不显示聚簇相的迹象。考虑玩具例子：测度完全支撑于 $\{\pm1\}^N$ 中恰好 $e^{N\Sigma}$ 个构型集，每集为一个簇 α，概率为 $w=e^{-N\Sigma}$。设同簇任意两构型重叠为 q_1，异簇为 $q_0<q_1$。虽然实际构造这种测度可能困难，暂忽略该问题。两独立构型同簇的概率为 $e^{N\Sigma}w^2=e^{-N\Sigma}$，所以

$$P(q)=(1-e^{-N\Sigma})\delta(q-q_0)+e^{-N\Sigma}\delta(q-q_1). \tag{12.38}$$

[15]原注：这是统计物理的惯用术语，不要与理论计算机科学中的复杂度混淆。

它趋于 $\delta(q-q_0)$，和顺磁相一样。

ϵ 耦合给出聚簇相的第一个迹象。式 (12.33) 的耦合使测度倾斜，罕见重叠获得有限概率。容易算得

$$d_*(\epsilon) \equiv \lim_{N\to\infty} d(\epsilon) = \begin{cases} (1-q_0)/2, & \epsilon < \epsilon_c, \\ (1-q_1)/2, & \epsilon > \epsilon_c, \end{cases} \tag{12.39}$$

其中 $\epsilon_c = \Sigma/[\beta(q_1-q_0)]$。$T \downarrow T_c$ 时，簇逐渐减少，$\Sigma \to 0$，故 $\epsilon_c \downarrow 0$。

此例的图景基本正确，但簇的性质只在一定精度和高概率意义下成立。

预期在 $(T_c, T_d']$ 中，$d_*(\epsilon)$ 在某个 $\epsilon_c > 0$ 处不连续，且趋近 T_c 时 $\epsilon_c \downarrow 0$。一般 ϵ 耦合算得的 T_d' 并不等于聚簇转变温度。我们实际估计的是样品 J 中，平衡构型 σ 与参考 s 有重叠 q 的指数小概率 $P(q \mid s, J)$。$d(\epsilon)$ 是该概率的某个有理函数对 s, J 的期望。从第 5 章以来已多次看到，指数小或指数大的量通常不依概率集中，$d(\epsilon)$ 可能由指数罕见样品主导。办法也是已知的：取对数！因此定义势[16]

$$V(q) = -\lim_{N\to\infty} \frac{1}{N\beta} \mathbb{E}_{s,J}\{\log P(q \mid s, J)\}. \tag{12.40}$$

参考构型仍从 Boltzmann 分布抽取，即

$$\mathbb{E}_{s,J}(\cdots) = \mathbb{E}_J \left\{ \frac{1}{Z_J} \sum_s e^{-\beta E_J(s)} (\cdots) \right\}. \tag{12.41}$$

若如预期那样，$\log P(q \mid s, J)$ 依概率集中，便有 $P(q \mid s, J) \doteq e^{-NV(q)}$。**译注：** 最后的指数按定义应含 β，即 $e^{-N\beta V(q)}$；集中也应针对归一化的 $N^{-1}\log P$。另外 $0 \le d \le 1$，指数罕见样品对其无条件期望的绝对贡献至多为其概率，不能单独产生非零的主导极限。原文对平均顺序及罕见样品的解释尚不足以证明 $T_d' \neq T_d$，这里保留其动机而不认证该论证。

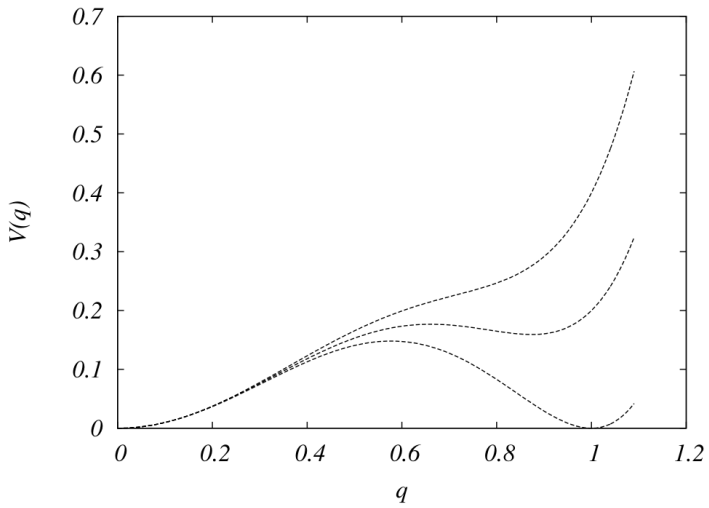


图 12.4: 不同温度下 $V(q)$ 的定性形状。很高温时（未画）势为凸；低于 T_d 后出现次级极小值。两极小值之差为 $V(q_1) - V(q_0) = T\Sigma$。本例 $q_0 = 0$ 不随温度变。取自 Part C PDF 第 90 页（原 258）。

[16] 原注：应引入分辨率，将重叠限制在 q 附近的窗口内；窗口宽可在 $N \to \infty$ 之后趋零。

习题 12.11. 考虑式 (12.38) 玩具模型的精化：

$$P(q \mid s,J) = (1-e^{-N\Sigma(s,J)})G_{q_0(s,J);b_0/(N\beta)}(q) + e^{-N\Sigma(s,J)}G_{q_1(s,J);b_1/(N\beta)}(q),$$

其中 $G_{a;b}$ 为均值 a、方差 b 的 *Gaussian* 分布。b_0, b_1 为常数；在式 (12.41) 的正确联合分布下，$\Sigma(s,J), q_0(s,J), q_1(s,J)$ 为独立 *Gaussian* 变量，均值依次为 $\overline{\Sigma}, \overline{q}_0, \overline{q}_1$，方差依次为 $\delta\Sigma^2/N, \delta q_0^2/N, \delta q_1^2/N$。为简单起见假设 $\delta\Sigma^2 < 2\overline{\Sigma}$，计算 $P(q)$ 和 $d(\epsilon)$。证明势由两段抛物线给出：

$$V(q) = \min\left\{ \frac{(q-\overline{q}_0)^2}{2b_0}, \frac{(q-\overline{q}_1)^2}{2b_1} + \frac{\overline{\Sigma}}{\beta} \right\}. \tag{12.42}$$

译注： 源概率式有一个多余右括号，排版时仅配平。精确 Gaussian 的 $\Sigma(s,J)$ 有非零概率为负，使第一权重为负；q_0, q_1 的无界 Gaussian 也超出自旋重叠的 $[-1,1]$。因此该模型作为有限 N 精确概率分布需截断等补充，不能仅由给定方差条件保证有效；正文保留原题及其形式渐近结论。

仅少数模型（主要全连接 p 自旋玻璃）的 $V(q)$ 已由复本法精确计算。其预期定性行为见图 12.4：β 小时势凸；增大到 β_* 后失去凸性；当 $\beta > \beta_d = 1/T_d$，在 $q_1(\beta) > q_0(\beta)$ 处出现次级极小值，指示指数多个簇的存在。同簇构型典型重叠为 q_1，异簇为 q_0，两极小值之差给出复杂度 $V(q_1) - V(q_0) = T\Sigma$。

在已精确计算此势的模型中，这样得到的 T_d 与动力学剧烈变慢一致。更准确地说，适当定义的 Glauber 类动力学弛豫时间，在 $T > T_d$ 有限，在 $T < T_d$ 随系统大小指数发散。[17]

12.3.6 克隆与复杂度函数

若各簇权重不同，更合适的描述是复杂度函数。对构型簇 α，将配分函数限制在簇内即可定义自由能 F_α。一种限制方式是选参考构型 $\sigma_0 \in \alpha$，只对到它的距离小于 $N\delta$ 的构型求和，其中 $(1-q_1)/2 < \delta < (1-q_0)/2$。以 $\mathcal{N}_\beta(f)$ 表示 $F_\alpha = Nf$ 的簇数，更准确地说，是在每个 F_α/N 点放单位质量的未归一化测度。预期满足

$$\mathcal{N}_\beta(f) \doteq \exp\{N\Sigma(\beta,f)\}. \tag{12.43}$$

率函数 $\Sigma(\beta,f)$ 称为复杂度函数。若按上述适当截断定义簇，预期除去 Boltzmann 权重指数小的构型集，它们互不重叠。因此总配分函数为

$$Z = \sum_\alpha e^{-\beta F_\alpha} \doteq \int e^{N[\Sigma(\beta,f)-\beta f]}\, df \doteq e^{N[\Sigma(\beta,f_*)-\beta f_*]}, \tag{12.44}$$

这里像第 2.4 节一样用了鞍点法，$f_* = f_*(\beta)$ 满足 $\partial\Sigma/\partial f = \beta$。[18]

固定 β 求完整的 $\Sigma(\beta,f)$ 很有价值。*克隆方法*高效但不严格，这里概述基本思想，应用留待后章。引入 m 个相同克隆，除被限制在同簇之外，彼此不相互作用。实际可约束两两 Hamming

[17] 译注：这是原稿对该批可解模型的叙述；未推广为任意无序系统和任意弛豫时间定义的定理。

[18] 译注：导数条件适用于可微内点鞍点；若极大值在可容许自由能区间边界，须另作边界优化。指数等价不指定有限 N 前因子。

距离小于 $N\delta$，δ 仍在上述区间。克隆系统的配分函数为

$$Z_m = \sum_{\sigma^{(1)},\dots,\sigma^{(m)}}{}' \exp\bigl\{-\beta E(\sigma^{(1)})\cdots-\beta E(\sigma^{(m)})\bigr\}. \tag{12.45}$$

撇号表示全部克隆处于同簇。[19]将求和按簇拆开：

$$Z_m = \sum_{\alpha}\sum_{\sigma^{(1)},\dots,\sigma^{(m)}\in\alpha} e^{-\beta E(\sigma^{(1)})\cdots-\beta E(\sigma^{(m)})} = \sum_{\alpha}\Bigl(\sum_{\sigma\in\alpha} e^{-\beta E(\sigma)}\Bigr)^m. \tag{12.46}$$

然后如普通配分函数一样得到

$$Z_m = \sum_{\alpha} e^{-\beta m F_\alpha} \doteq \int e^{N[\Sigma(\beta,f)-\beta m f]}\,df \doteq e^{N[\Sigma(\beta,\widehat{f})-\beta m\widehat{f}]}, \tag{12.47}$$

$\widehat{f}=\widehat{f}(\beta,m)$ 满足 $\partial\Sigma/\partial f=\beta m$。定义每克隆自由能密度

$$\Phi(\beta,m) = -\lim_{N\to\infty}\frac{1}{\beta m N}\log Z_m. \tag{12.48}$$

鞍点估计表明，它与复杂度通过 Legendre 变换联系：

$$\Phi(\beta,m) = f - \frac{1}{\beta m}\Sigma(\beta,f), \qquad\qquad \frac{\partial\Sigma}{\partial f}=\beta m. \tag{12.49}$$

若暂时忘记 m 是整数，并允许将 Φ 延拓到非整数 m，就能反演此变换来计算复杂度。[20][21]

习题 12.12. *在 REM 中，构型 $i,j\in\{1,\dots,2^N\}$ 的自然重叠为 $Q(i,j)=\delta_{ij}$。固定参考 j_0，扰动能量为 $E'(\epsilon,j)=E_j-N\epsilon\delta_{j,j_0}$；额外的 N 因子使耦合项具有典型广延尺度。*

1. *高温相 $\beta<\beta_c=2\sqrt{\log 2}$ 中，证明在 $\epsilon=(\log 2)/\beta-\beta/4$ 有相变。*

2. *低温相 $\beta>\beta_c$ 中，证明相变在 $\epsilon=0$ 发生。*

因此 REM 在任意 β 都有簇，每簇仅一个构型，故 $\Sigma(\beta,f)=\log 2-f^2$，不依赖 β。计算下面的势，证明它与克隆方法相容：

$$\Phi(\beta,m)=\begin{cases} -\dfrac{\log 2}{\beta m}-\dfrac{\beta m}{4}, & m<\beta_c/\beta,\\[2mm] -\sqrt{\log 2}, & m>\beta_c/\beta. \end{cases} \tag{12.50}$$

译注：参考构型应按前述方法从该温度的平衡测度抽取，若 j_0 是与能量无关的固定指标，题给高温临界耦合不成立。单构型簇的 f 就是能量密度，复杂度公式只在有典型构型的允许区间适用，区间外不能用负复杂度当作典型簇数。

[19]译注：源指数在各负能量项之间只写省略号；根据下一式，应理解为 $-\beta\sum_{a=1}^{m}E(\sigma^{(a)})$，而非负能量的乘积。上式保留源写法。

[20]原注：它与复本方法的相似并非偶然。不过复本是为处理淬火无序而引入，克隆方法则更一般。

[21]译注：延拓及选择物理解是额外步骤；Legendre 反演还受可恢复的凹包络及鞍点可达区间限制，不能由整数值本身保证任意复杂度支的唯一恢复。

12.4 例：SK 模型的相图

若干平均场模型已用复本方法求解。有时同一模型具有性质不同的两个或更多玻璃相，确定相图就尤其困难。经典例子是具有铁磁偏置耦合的 SK 模型，仍取 N 个 Ising 自旋，能量为

$$E(\sigma) = -\sum_{(i,j)} J_{ij}\sigma_i\sigma_j, \tag{12.51}$$

求和遍及无序对，各 J_{ij} 为独立 Gaussian 变量，均值 J_0/N、方差 $1/N$。它在某种意义上插值于第 2.5.2 节的 Curie–Weiss 模型（$J_0 \to \infty$）与第 8 章的无偏 SK 模型（$J_0 = 0$）之间。[22]

图 12.5 以 J_0, T 为参数，含顺磁相 P、铁磁相 F、对称自旋玻璃相 SG、混合铁磁自旋玻璃相 F-SG。可先用平均磁化强度与重叠简单刻画。由于 $E(\sigma) = E(-\sigma)$，对任意 J_0, T 恒有 $\langle\sigma_i\rangle = 0$。为破缺对称性，加入 $-B\sum_i \sigma_i$，在热力学极限之后令 $B \to 0$，定义

$$m = \lim_{B\to 0^+}\lim_{N\to\infty} \mathbb{E}\langle\sigma_i\rangle_B, \qquad\qquad q = \lim_{B\to 0^+}\lim_{N\to\infty} \mathbb{E}\big(\langle\sigma_i\rangle_B^2\big). \tag{12.52}$$

由于耦合分布在位置置换下不变，它们不依赖 i。P 相有 $m = q = 0$；SG 相有 $m = 0, q > 0$；F 与 F-SG 相都有 $m > 0, q > 0$。

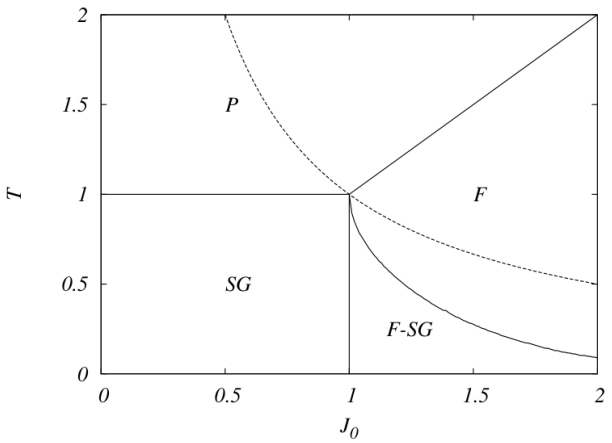


图 12.5: 零磁场 SK 模型相图。随温度 T 与铁磁偏置 J_0 改变，有 P、F、SG 和 F-SG 四相。实线分隔各相，虚线表示 Nishimori 温度。取自 Part C PDF 第 94 页（原 262）。

用重叠分布可作更完整的描述。自旋反演对称性使 $P(q) = P(-q)$。各相的热力学极限形状见图 12.6。P 相为零处单位质量的单 δ 峰，两独立 Boltzmann 构型重叠以高概率接近零。F 相集中于 $\pm q(J_0, T)$，各有一半权重：随机构型等概率落入局域磁化为 $\{m_i\}$ 或 $\{-m_i\}$ 的两个态之一。两次独立抽样，或者同态，重叠为 $q = N^{-1}\sum_i m_i^2$；或者异态，重叠为 $-q$，两者概率各半。

SG 相支集为对称区间 $[-q_{\max}, q_{\max}]$，$q_{\max}$ 依赖 J_0, T；F-SG 相则为两区间 $[-q_{\max}, -q_{\min}] \cup [q_{\min}, q_{\max}]$。后两相中整段重叠范围具有非零概率，提示前节意义下的大量准态。

[22] 译注：与 Curie–Weiss 的对应须以铁磁尺度为单位、相应缩放温度理解；固定原温度直接令 $J_0 \to \infty$ 是极强铁磁耦合极限。

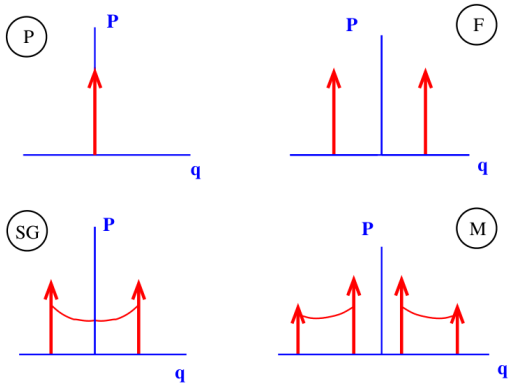


图 12.6: 铁磁偏置 SK 模型四相中 $P(q)$ 的典型形状。原图右下用 M 表示正文所称 F-SG 混合相。取自 Part C PDF 第 95 页（原 263）。

为消除自旋反演对称性带来的简并，有时加入磁场，并如式 (12.52) 取极限，定义非对称分布

$$P_+(q) = \lim_{B\to 0^+} \lim_{N\to\infty} P_B(q). \tag{12.53}$$

有些出人意料的是，$q<0$ 时 $P_+(q)=0$，$q>0$ 时 $P_+(q)=2P(q)$，即它是重叠绝对值的分布。[23]

习题 12.13. *考虑带磁场的 Curie–Weiss 模型，参见第 2.5.2 节。画相图并计算渐近重叠分布，讨论其在不同温度、磁场下的定性特点。*

对相图推导感兴趣的读者，可从习题 8.12 开始，其中已用复本法推导部分边界。P-F 边界通过解关于 q,μ,m 的 RS 方程 (8.68) 得到；P-SG 与 F-M 线由 AT 稳定性条件 (8.69) 得到。SG 与 F-SG 边界更难，因为两侧都是玻璃相，不能由 RS 解得到。已知它近乎竖直，但无简单表达式。

Nishimori 温度由式 (12.7) 得到 $T_{\mathrm{N}}=1/J_0$，$T=1/J_0$ 通常称为 Nishimori 线；线上每自旋内能为 $U/N=-J_0/2$。这条线不进入任一玻璃相，与一般论证相符。[24]

SK 模型的重要特点是，P 与 SG、F 与 F-SG 之间玻璃相的出现都是连续转变，因此伴随非线性磁化率 χ_{SG} 发散。下一习题为熟悉复本方法的读者勾勒论证。

[23] 译注：$q=0$ 的原子质量若存在应单独保留，不能将该点质量翻倍。上述关系是这里模型的叙述，并非任意规范对称系综的普遍结论。

[24] 译注：此处应使用第 12.2.2 节已指出的条件正号。对均值 J_0/N、方差 $1/N$ 的 Gaussian 耦合，$\mathcal{P}(J)/\mathcal{P}(-J)=e^{2J_0J}$，从而 $\beta_{\mathrm{N}}=J_0$。有限 N 的独立无序对有 $N(N-1)/2$ 条，习题 12.8 给出 $U/N=-J_0(N-1)/(2N)$，原值是热力学极限。

习题 12.14. 用复本法计算 *SK* 模型的非线性磁化率 $\chi_{\mathrm{SG}} = (\beta^2/N)\sum_{i\neq j}(\langle\sigma_i\sigma_j\rangle - \langle\sigma_i\rangle\langle\sigma_j\rangle)^2$。证明

$$\begin{aligned}\chi_{\mathrm{SG}} &= \lim_{n\to 0}\frac{\beta^2}{N}\sum_{i\neq j}\Bigg[\binom{n}{2}^{-1}\sum_{(ab)}\langle\sigma_i^a\sigma_i^b\sigma_j^a\sigma_j^b\rangle \\ &\qquad - \binom{n}{3}^{-1}\sum_{(abc)}\langle\sigma_i^a\sigma_i^b\sigma_j^a\sigma_j^c\rangle + \binom{n}{4}^{-1}\sum_{(abcd)}\langle\sigma_i^a\sigma_i^b\sigma_j^c\sigma_j^d\rangle\Bigg] \\ &= N\lim_{n\to 0}\int\prod_{(ab)}(dQ_{ab}\,d\lambda_{ab})e^{-N\mathcal{G}(Q,\lambda)}A(Q), \end{aligned} \tag{12.54}$$

沿用式 (8.30) 的记号，$(a_1\cdots a_k)$ 对互异复本指标的 k 元组求和，且

$$A(Q) \equiv \binom{n}{2}^{-1}\sum_{(ab)}Q_{ab}^2 - \binom{n}{3}^{-1}\sum_{(abc)}Q_{ab}Q_{ac} + \binom{n}{4}^{-1}\sum_{(abcd)}Q_{ab}Q_{cd}. \tag{12.55}$$

按以下思路分析发散。式 (12.54) 的主导贡献应来自鞍点，高温相中为 *RS* 鞍点 $Q_{ab}=q$ 处的 $A(Q)$；但 $n\to 0$ 时该贡献显然消失。因此必须考虑鞍点附近涨落。$A(Q)$ 中每项 $Q_{ab}Q_{cd}$ 都给出 $1/N$ 乘 *Hessian* 逆矩阵的相应矩阵元。*Hessian* 非奇异时矩阵元有限，$1/N$ 抵消前因子 N，故磁化率有限；达到 *AT* 不稳定线时，逆矩阵元发散，故 χ_{SG} 发散。

译注： 原题与前定义相比省略了 $i=j$ 项；该项在有限正温下只给有界对角贡献，但不是同一有限 N 定义。源式两处交叉项系数为 -1，而展开 $(\langle\sigma_i\sigma_j\rangle-\langle\sigma_i\rangle\langle\sigma_j\rangle)^2$ 需 -2。在各和按相应二项式归一为平均的解释下，源 $A(Q_{ab}=q)=q^2-q^2+q^2=q^2$，并非一般随 $n\to 0$ 消失；其声称的抵消缺少该系数。最后的积分式还未说明 β^2、归一化测度及有限 N 对角项如何处理。原式与思路均照录，不将此题当作完整严格推导；RS 涨落及复本极限本来也需额外论证。

注释

Edwards–Anderson 模型的模拟综述见 Marinari、Parisi 和 Ruiz-Lorenzo（1997）。平均场自旋玻璃的数学结果见 Talagrand（2003），较短的近期综述为 Guerra（2005）。稀释自旋玻璃由 Viana 和 Bray（1988）引入。

规范变换的推论由 Hidetoshi Nishimori 及合作者得到，详见 Nishimori（2001）。相变中的纯态，以及 Gibbs 测度分解为纯态叠加的概念，见 Georgii（1988）。

自旋玻璃磁化率的发散特别重要，因为该量可以在零场测量。Monod 和 Bouchiat（1982）的实验提供发散的证据，支持真实三维自旋玻璃在零场有有限温自旋玻璃转变。

两个转变温度 $T_c < T_d$ 的存在最先由 Kirkpatrick、Thirumalai 和 Wolynes 讨论（Kirkpatrick 和 Wolynes，1987；Kirkpatrick 和 Thirumalai，1987），他们指出其与结构玻璃理论的关联。特别是 Kirkpatrick 和 Thirumalai（1987）讨论了 p 自旋玻璃。此路线及其动力学意义的综述见 Bouchaud、Cugliandolo、Kurchan 和 Mézard（1997）。

ϵ 耦合方法由 Caracciolo、Parisi、Patarnello 和 Sourlas（1990）引入。用克隆研究复杂度函数的思想来自 Monasson（1995）；势方法由 Franz 和 Parisi（1995）引入。

第十三章　桥接

前三章说明，来源迥异的问题可以统一表为因子图。其背后的数学结构，即变量间概率依赖关系的局域性，也见于许多概率推断问题，为这一领域提供了另一种统一视角。另一方面，局域性是通过 Monte Carlo 技术从复杂分布中采样的重要条件。

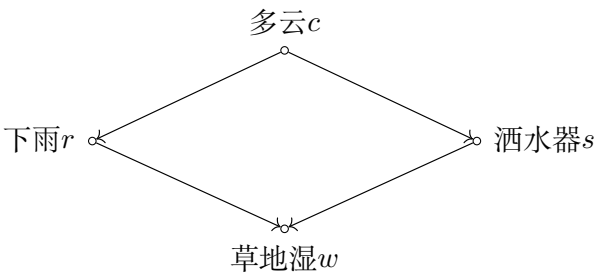
第 13.1 节介绍统计推断的基本术语和简单例子。统计推断本身是有许多重要应用的领域，涵盖人工智能、建模和统计学。这里着重说明如何将编码理论、统计力学与组合优化视为推断问题。

第 13.2 节发展一个适用于这些问题的一般工具：第 4.5 节已介绍的 Monte Carlo Markov 链（MCMC）技术。这往往是一种强有力的方法。Monte Carlo 采样也可视为统计推断方法，而 Monte Carlo 动力学是第 10.2.3、11.4 节所述局部搜索策略的一个简单原型。解码、约束满足问题或玻璃相中遇到的许多困难，都与 MCMC 动力学的剧烈慢化有关。我们给出若干例子的简单数值实验，确定相图中因 MCMC 慢化而使采样 / 推断算法表现不佳的区域。最后，第 13.3 节用一种相当一般的论证，估计 MCMC 须运行多长时间，才能产生近似独立、服从所需分布的样本。

13.1　统计推断

13.1.1　Bayesian 网络

人工智能和统计学中，通常用 Bayesian 网络来表述推断问题。尽管这类问题都可以表为因子图，仍值得简要介绍这种替代语言。一个著名的简单例子是 “下雨—洒水器” 网络。



$p(r \mid c)$	$c=0$	$c=1$
$r=0$	0.8	0.3
$r=1$	0.2	0.7

$p(s \mid c)$	$c=0$	$c=1$
$s=0$	0.1	0.7
$s=1$	0.9	0.3

$p(w \mid r,s)$	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
$w=0$	0.1	0.2	0.2	0.1
$w=1$	0.9	0.8	0.8	0.9

图 13.1: 下雨—洒水器 Bayesian 网络。箭头与三张条件概率表按 Part C PDF99（原 267）重排，所有表值保留原稿。

例 13.1. 一位统计学家在公园散步时，注意到草地湿了。可能有两个原因：或者昨夜下过雨，或者早晨打开洒水器浇过草坪。这两件事又都与过去 *24* 小时的天气状况相关。

稍作思考后，统计学家将这些考虑形式化为图 *13.1* 的概率模型。模型有四个随机变量：多云、下雨、洒水器和草地湿，均取值于 $\{0,1\}$，分别表示假和真。变量构成有向图的顶点，有向边直观地对应因果关系。四个变量的联合概率分布用与边关联的条件概率给出。用各变量的英文首字母表示，有

$$p(c,s,r,w) = p(c)\,p(s \mid c)\,p(r \mid c)\,p(w \mid s,r). \tag{13.1}$$

三个条件概率见图中的表。对于当天是否多云，假设均匀先验 $p(c=0)=p(c=1)=1/2$。

已观察到草地湿，我们可能希望判断最可能的原因是下雨还是洒水器。这相当于计算边缘概率

$$p(s \mid w=1) = \frac{\sum_{c,r} p(c,s,r,w=1)}{\sum_{c,r,s'} p(c,s',r,w=1)}, \tag{13.2}$$

$$p(r \mid w=1) = \frac{\sum_{c,s} p(c,s,r,w=1)}{\sum_{c,r,s'} p(c,s',r,w=1)}. \tag{13.3}$$

使用图中的数值，得到 $p(s=1 \mid w=1) \approx 0.40$、$p(r=1 \mid w=1) \approx 0.54$：草地湿最可能是由于下雨。

图 *13.2* 给出式 (13.1) 及条件分布 $p(c,s,r \mid w=1)$ 的因子图表示。从因子图可清楚看到：除通过 c 的关系产生的依赖外，观察 $w=1$ 又在变量 s,r 之间引入额外依赖。请读者画出边缘分布 $p(c,s,r)$ 的因子图。

译注（原数值疑点）： 保留原表和原结论。用所列三表及均匀先验直接枚举，实际得到 $p(s=1 \mid w=1) \approx 0.598921$、$p(r=1 \mid w=1) \approx 0.455036$，与原文数值及排序不符；这里不自行改动表值来使之匹配。

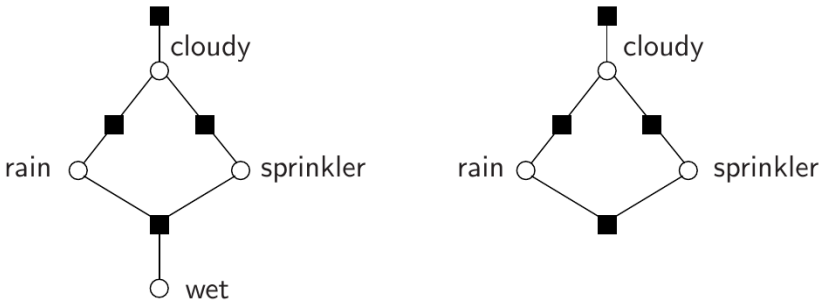


图 13.2: 左：图 13.1 的因子图。右：观察变量 w 后同一网络的因子图。图中 cloudy、rain、sprinkler、wet 分别为多云、下雨、洒水器、草地湿。

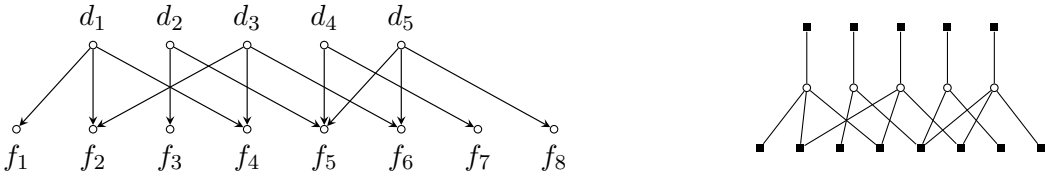


图 13.3: 左：QMR-DT Bayesian 网络的简单例子，13 条有向边按原图重建。右：给定发现 $f_1, \ldots, f_8$ 后，疾病 $d_1, \ldots, d_5$ 条件分布的因子图；上方五个方节点为先验因子。

一般地，Bayesian 网络是定义图顶点上变量概率分布的有向无环图 $G = (V, E)$。有向图是为每条边选定方向、即选定相邻顶点次序的普通图，并且没有环。若 (u, v) 是 G 的有向边，就称 $u \in V$ 是 v 的父节点，写作 $u \in \pi(v)$。每个顶点 v 关联随机变量 X_v；为简单起见，假设所有变量取值于同一个有限集合 $\mathcal{X}$。随机变量 $\{X_v : v \in V\}$ 的联合分布由条件分布 $\{p(x_v \mid x_{\pi(v)})\}$ 决定，其中 $\pi(v)$ 为 v 的父节点集、$x_{\pi(v)} = \{x_u : u \in \pi(v)\}$：

$$p(x) = \prod_{v \in \pi(G)} p(x_v) \prod_{v \in G \setminus \pi(G)} p(x_v \mid x_{\pi(v)}), \tag{13.4}$$

这里 $\pi(G)$ 是 G 中没有父节点的顶点集。

一类一般的统计推断问题可表述如下：给定 Bayesian 网络，即有向图 G 及相应条件概率分布 $\{p(x_v \mid x_{\pi(v)})\}$。变量子集 $O \subseteq V$ 被观察到取值为 x_O，问题是计算条件分布 $p(x_{V \setminus O} \mid x_O)$ 的边缘分布。

对给定网络 G 和被观察变量集合 O，容易推广图 13.2 的过程，得到这一条件分布的因子图表示。一般规则如下：

1. 为每个未被观察的变量，即 $x_{V \setminus O}$ 中的变量，设置变量节点；
2. 对 $\pi(G) \setminus O$ 中的每个变量，添加只连接它的度 1 函数节点；
3. 对不在 $\pi(G)$ 中的每个未被观察顶点 v，添加连接 v 及其所有父节点的函数节点；
4. 最后，为每个被观察变量 u 添加连接其所有父节点的函数节点。

下面的例子说明 Bayesian 网络的实际用途。

例 13.2. *Quick Medical Reference–Decision Theoretic* (*QMR-DT*) 网络是为自动医学诊断开发的两层 *Bayesian* 网络，图 *13.3* 给出示意例子。上层变量 $d_1,\dots,d_N$ 代表疾病，下层变量 $f_1,\dots,f_M$ 代表症状或发现。两类变量均为二元变量。当疾病 d_i 可能引起发现 f_a 时，用边连接两者。这类蕴含关系网络依据积累的医学经验构建。

网络还需要两类概率分布。对每种疾病 d_i，给定其发生的先验概率 $P(d_i)$；对每项发现，给定各疾病组合下出现该发现的条件概率。后者通常采用所谓“带噪或”(*noisy-OR*) 形式：

$$P(f_a=0\mid d)=\frac{1}{z_a}\exp\left\{-\sum_{i=1}^{N}\theta_{ia}d_i\right\}. \tag{13.5}$$

此网络用于诊断：根据对病人的观察设置发现的取值，再由这一症状组合计算任一疾病确实存在的边缘概率。

13.1.2 编码、统计物理与组合优化中的推断

本书遇到的若干问题都可以用推断语言重新表述。

先从纠错码解码说起。第 六章讨论过，逐符号 MAP 解码要求在给定信道输出时计算输入符号的边缘分布。对于 LDPC 及相关码系综，输入符号间的依赖由奇偶校验约束引入。待取边缘的联合分布具有自然的图表示，尽管我们使用的是因子图而非 Bayesian 网络。引入有限温解码后，还可以将整词 MAP 解码视为一族单参数推断问题的零温极限。

统计力学模型主要关注局域可观测量关于 Boltzmann 测度的期望和协方差。例如，第 2.5 节的 Ising 铁磁体顺磁—铁磁转变可由磁化强度 $M_N(\beta,B)=\langle\sigma_i\rangle_{\beta,B}$ 定位。计算关联函数 $C_{ij}(\beta,B)=\langle\sigma_i;\sigma_j\rangle_{\beta,B}$ 等协方差，是此前简单推断问题的自然推广。

最后考虑组合优化。具体地，假设可行解为变量赋值 $x=(x_1,\dots,x_N)\in\mathcal{X}^N$，其代价可写成局域项之和：

$$E(x)=\sum_{a}E_a(x_a), \tag{13.6}$$

其中 x_a 是变量 $(x_1,\dots,x_N)$ 的子集。记最优解上的均匀分布为 $p_*(x)$。最小能量可以写成关于该分布的期望之和，$E^*=\sum_a[\sum_x p_*(x)E_a(x_a)]$。当然，$p_*(x)$ 未必有简单表示，计算 E^* 因而可能比简单推断困难得多。[1]

可以通过“软化”分布 $p_*(x)$ 克服这一问题。一种选择是像第 4.6 节那样引入有限温度，定义 $p_\beta(x)=\exp[-\beta E(x)]/Z$。当 β 足够大时，它集中在最优解上；同时在任意 β 下，它都有显式表示，除归一化常数 Z 的值之外。

要很好地估计 E^*，β 应取多大？以下习题在相当一般的假设下给出答案。

习题 13.1. 假设代价函数 $E(x)$ 取整数值，令 $U(\beta)=\langle E(x)\rangle_\beta$。由式 (13.6) 的形式，计算 $U(\beta)$ 本质上等价于统计推断。进一步假设 $\Delta_{\max}=\max[E(x)-E^*]$ 受关于 N 的某个多项式所界。证明

$$0\le\frac{\partial U}{\partial T}\le\frac{1}{T^2}\Delta_{\max}^2|\mathcal{X}|^N e^{-1/T},\qquad T=1/\beta. \tag{13.7}$$

由此推出，取 $T=\Theta(1/N)$ 时，可使任意固定 $\varepsilon>0$ 满足 $|U(\beta)-E^*|\le\varepsilon$。

[1] 例如，考虑 MAX-SAT 问题，令 $E(x)$ 为赋值 x 下未满足子句的数目。公式可满足时，$p_*(x)$ 正比于各子句特征函数的乘积，见例 9.7；反之，则没有已知的显式表示。

许多重要情形实际上可使用高得多的温度，即小得多的 β。第 二章给出过 $U(\beta) = E^* + E_1(N)e^{-\beta} + O(e^{-2\beta})$ 的例子，其中 $E_1(N)$ 随 N 多项式增长。在这些情形下，预期 $\beta = \Theta(\log N)$ 已足够大。

13.2 Monte Carlo 方法：通过采样进行推断

考虑从联合分布 $p(x)$、$x = (x_1, \ldots, x_N) \in \mathcal{X}^N$ 计算边缘概率 $p(x_i = x)$ 的统计推断问题。给定从 $p(x)$ 抽取的 L 个独立同分布样本 $\{x^{(1)}, \ldots, x^{(L)}\}$，可用其中满足 $x_i = x$ 的样本比例估计所需边缘概率。

原则上，第 4.5 节的 MCMC 方法可以产生来自 $p(x)$ 的“近似独立同分布”样本，因而可视为适用于多种背景的一般推断策略。

因子图所表达的相互作用局域性非常有用，因为它使我们容易在 x 中产生局部变化，例如只改变一个 x_i 或少数变量。这通常只改变少数相容函数的值，因而只使 $p(x)$、用物理语言说即构型能量，发生小变化。[2] 给定 x 时能产生能量接近的新构型，是 MCMC 有效工作的重要因素；大幅提高系统能量的移动通常会被 MCMC 规则拒绝。

还应注意，例如 MCMC 这样的采样，只能用来估计涉及少量变量的边缘分布或期望。若试图用某个特定构型 x 在样本中出现的次数 $L(x)$ 来估计其概率，会非常困难：要有任何精度，至少需要 $1/p(x)$ 个样本，而它通常随 N 指数增长。

13.2.1 LDPC 码

取第 十一章 LDPC 系综中的码 $\mathcal{C}$，通过转移概率为 $Q(y \mid x)$ 的二元输入无记忆对称信道通信。第 六章式 (6.3) 表明，给定输出 y 时输入 x 的条件分布为

$$P(x \mid y) = \frac{1}{Z(y)} \mathbf{1}(x \in \mathcal{C}) \prod_{i=1}^{N} Q(y_i \mid x_i). \tag{13.8}$$

使用码成员函数的显式表示，可写成

$$P(x \mid y) = \frac{1}{Z(y)} \prod_{a=1}^{M} \mathbf{1}(x_{i_1^a} \oplus \cdots \oplus x_{i_k^a} = 0) \prod_{i=1}^{N} Q(y_i \mid x_i). \tag{13.9}$$

逐符号 MAP 解码要求计算这一分布的边缘 $P^{(i)}(x_i \mid y)$。看看如何通过 MCMC 采样近似完成它。

不幸的是，第 4.5 节的简单 MCMC 算法，即单比特翻转并使用满足细致平衡的接受检验，在此不能直接应用。在任何合理的 LDPC 码中，每个 x_i 至少参与一个奇偶校验约束。假设从服从式 (13.9) 的随机构型 x 出发。由于其概率非零，它满足全部奇偶校验约束。若提议翻转比特 x_i，新构型会违反所有涉及 x_i 的奇偶校验约束，因此任何满足细致平衡的规则都会拒绝这一移动。Markov 链因而可约，每个码字自成遍历分支，对采样毫无用处。

对好的码，允许一次翻转多个比特也不容易解决这一问题。第 11.2 节表明，从最小变量度为 2、或至少为 3 的 LDPC 系综抽取的码，其最小距离分别随块长对数发散或线性发散。为

[2] 这里并非声称此事总是成立，只是在许多感兴趣的例子中成立。

避免上述问题，必须同时翻转不少于最小距离的比特。另一方面，这种大移动也很可能被拒绝，因为它使似然 $\prod_{i=1}^{N} Q(y_i \mid x_i)$ 发生大而不可控的变化。

摆脱这一困境的一种方法，是引入“奇偶校验温度” γ 来软化校验约束，并定义分布

$$P_\gamma(x \mid y) = \frac{1}{Z(y,\gamma)} \prod_{a=1}^{M} e^{-\gamma E_a(x_{i_1^a} \cdots x_{i_k^a})} \prod_{i=1}^{N} Q(y_i \mid x_i). \tag{13.10}$$

这里，当 $x_{i_1^a} \oplus \cdots \oplus x_{i_k^a} = 0$ 时，能量项 E_a 取 0，否则取 2。当 $\gamma \to \infty$ 时，式 (13.10) 退化为式 (13.9)。现在的思路是用 MCMC 估计式 (13.10) 的边缘 $P_\gamma^{(i)}(x_i \mid y)$，再使用解码规则

$$x_i^{(\gamma)} \equiv \arg\max_{x_i} P_\gamma^{(i)}(x_i \mid y). \tag{13.11}$$

对任意有限 γ，这一方案相对逐符号 MAP 解码必然次优。特别地，式 (13.10) 给不属于码本 $\mathcal{C}$ 的字也赋予非零权重。不过，可以希望 γ 足够大时，这一方案能取得接近最优的比特错误率。

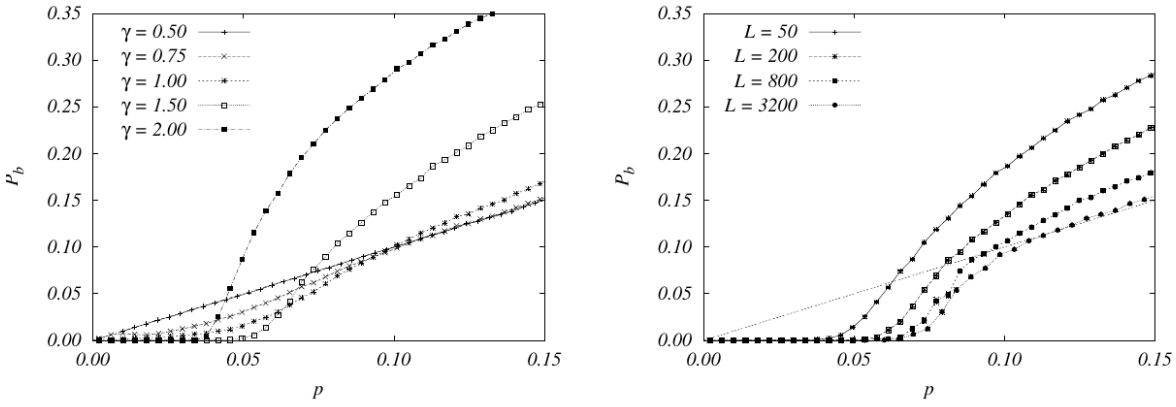


图 13.4: 通过 MCMC 采样解码 $(3,6)$ 系综的 LDPC 码，经翻转概率为 p 的 BSC 通信。比特错误率对 p 作图，块长固定 $N = 2000$，扫描数为 $2L$。左：$L = 100$，不同有效逆温度 γ。右：固定 $\gamma = 1.5$ 时随扫描数增加的性能改善。

还可以放弃按任意给定精度近似边缘 $P_\gamma^{(i)}(x_i \mid y)$ 的目标，进一步简化上述策略：让 Glauber 单比特翻转 MCMC 运行固定的计算时间，从这一过程提取边缘估计。图 13.4 给出从均匀随机构型开始运行 $2LN$ 步 Glauber 动力学的结果。每步均匀随机选择一个比特，并以下列概率翻转；其中 $x^{(i)}$ 为将 x 的第 i 个比特翻转所得构型：

$$w_i(x) = \frac{P_\gamma(x^{(i)} \mid y)}{P_\gamma(x^{(i)} \mid y) + P_\gamma(x \mid y)}. \tag{13.12}$$

⋆请读者推导 $w_i(x)$ 的显式表达式，并证明其计算所需操作数与块长无关。这里常将连续 N 次更新称为一次*扫描*，因为平均每个比特被提议翻转一次。在最后 L 次扫描中逐次记录 x_i，根据哪个值出现更多，令解码器输出 $x_i = 0$ 或 $x_i = 1$。

图 13.4 的数据对应翻转概率为 p 的 BSC。左图固定 $L = 100$、使用不同 γ。γ 较小时，比特错误率几乎与未编码时的 $P_b = p$ 无法区分。随着 γ 增大，奇偶校验被越来越严格地执行，低噪声时纠错能力改善。但在较高噪声下，行为有质的差别：当 $p \gtrsim 0.05$ 时，比特错误率随 γ 增

大。这一改变本质上来自动力学：用于从式 (13.10) 采样的 Markov 链越来越慢地失去对初态的记忆。均匀随机初态给出 $P_b = 1/2$，所以在 γ 很大且 p 超过某阈值时，算法所得错误率趋近 1/2。同图右侧的数据支持这一解释。

后续第?? 章将表明,在大块长极限下,此例无比特错误 MAP 解码的预测阈值为 $p_c \approx 0.101$。[3] 不幸的是，由于动力学缓慢，信道噪声接近这一阈值时，MCMC 解码器无法在实际中使用。

式 (13.10) 的单自旋翻转 MCMC 慢化，部分与硬约束模型 (13.9) 的可约性有关。一个初步直观图景是：γ 很大时，码字对应相互孤立、$P_\gamma(x \mid y) = \Theta(1)$ 的概率 “团块”，其间由 $P_\gamma(x \mid y) = \Theta(e^{-2\gamma})$ 或更小的低概率区域分隔。为了去相关，Markov 链须在低概率区域中停留很久，至少为码最小距离的量级，而这极少发生。这一粗略解释既不完整，也不完全正确；后续章节将进一步完善它。

13.2.2 Ising 模型

在简单统计力学模型上，可以理解导致 Glauber 动力学慢化的某些基本机制。考虑能量函数为

$$E(\sigma) = -\sum_{(ij)\in G} \sigma_i \sigma_j \tag{13.13}$$

的铁磁 Ising 模型。G 是有 N 个顶点的普通图，其具体结构依例子而定。Monte Carlo 方法用于在逆温度 β 下从 Boltzmann 分布 $p_\beta(\sigma)$ 采样。

仍关注 Glauber、即热浴动力学，但重标度时间：在无穷小时间间隔 dt 内，以概率 Ndt 在均匀随机选择的顶点 i 提议翻转。翻转按通常的热浴概率接受；其中 σ 为当前构型、$\sigma^{(i)}$ 为翻转自旋 σ_i 后的构型：

$$w_i(\sigma) = \frac{p_\beta(\sigma^{(i)})}{p_\beta(\sigma) + p_\beta(\sigma^{(i)})}. \tag{13.14}$$

先考虑平衡动力学，假设初态 $\sigma(0)$ 从平衡分布 $p_\beta(\cdot)$ 抽取，问需要多少 Monte Carlo 步、或者需等待多久，才能得到实际上独立的随机构型。监测平衡动力学的一种方便方法是计算时间关联函数

$$C_N(t) \equiv \frac{1}{N}\sum_{i=1}^{N} \langle \sigma_i(0)\sigma_i(t)\rangle. \tag{13.15}$$

平均 $\langle\cdot\rangle$ 同时针对 Monte Carlo 动力学的实现和初态 $\sigma(0)$。注意，$(1 - C(t))/2$ 为两个构型 $\sigma(0), \sigma(t)$ 中取值不同的自旋的平均比例。因此预期 $C(t)$ 随 t 下降，当两个构型充分去相关时渐近达到 0。[4]

[3] 译注：原稿章号为问号，保留其待定状态。

[4] 对于能量函数 (13.13) 的 Boltzmann 分布，每个自旋取 $+1, -1$ 的概率相同。

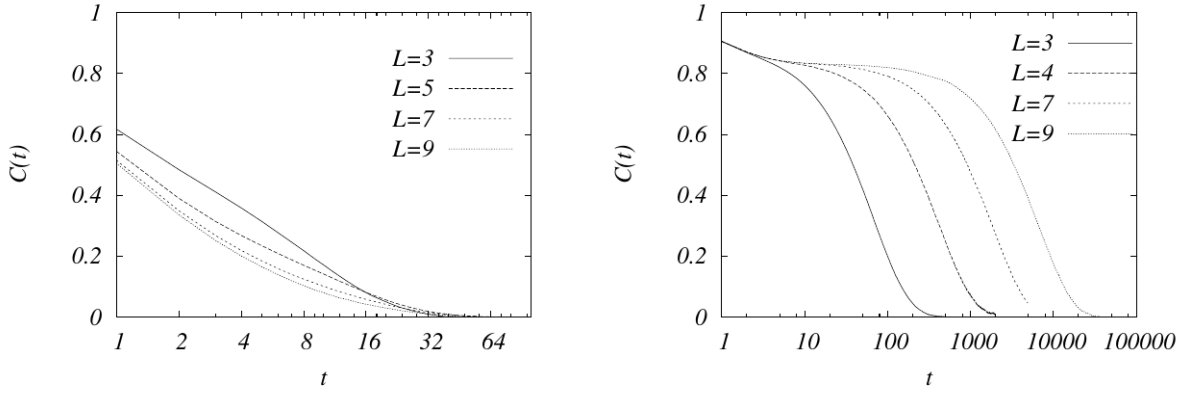


图 13.5: 边长 L 的二维网格上 Ising 模型的平衡关联函数。左：高温 $T=3$。右：低温 $T=2$。

读者可能会问，怎样从平衡 Boltzmann 分布抽取 $\sigma(0)$? 第 4.5 节已建议，可从任意构型出发，让 Markov 链运行足够多步，得到 “近似” 平衡构型。实践中，我们从均匀随机构型、即无穷温平衡构型初始化，运行 t_w 次扫描；将所得构型记为 $\sigma(0)$，再运行 t 次扫描测量 $C(t)$。t_w 的选择至关重要：一般而言，此过程产生的 $\sigma(0)$ 并不服从平衡分布，而依赖于 t_w；测得的关联函数也会依赖 t_w。为足够好地近似 $C(t)$，t_w 应取多大，是理论研究的重要课题。一个简单经验规则是：取较大的 t_w 测量 $C(t)$，再将 t_w 加倍，检查结果是否不变。*请读者据此编写一般图上 Ising 模型的 MCMC 程序，重现下面的数据。

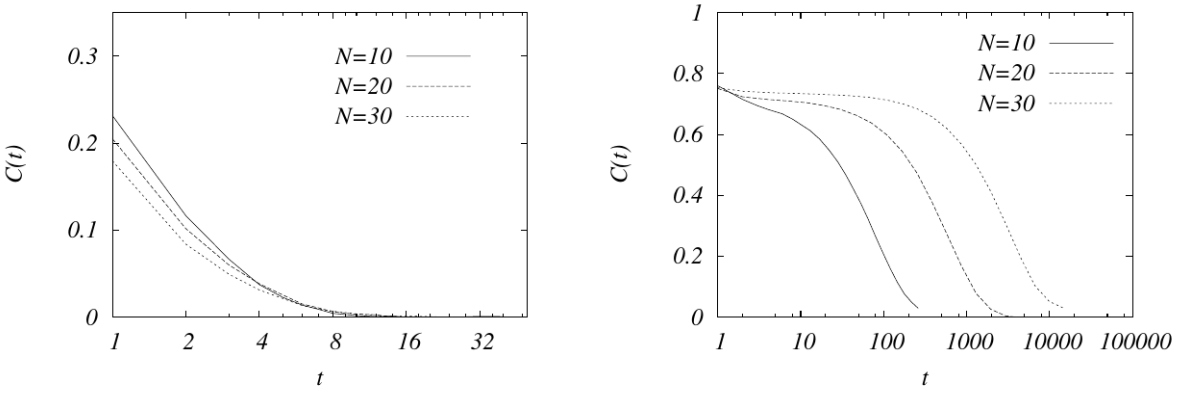


图 13.6: 来自 $\mathcal{G}_N(2,M)$ 系综、$M=2N$ 的随机图上 Ising 模型的平衡关联函数。左：高温 $T=5$。右：低温 $T=2$。

例 13.3. 先考虑边长为 L、取周期边界条件的二维网格 *Ising* 模型。顶点集为 $\{(x_1,x_2):1\le x_a\le L\}$。欧氏距离为 *1* 的顶点之间连边，另将 (L,x_2) 与 $(1,x_2)$、(x_1,L) 与 $(x_1,1)$ 相连。将此图的关联函数记为 $C_L(t)$。

第二章说明，该模型在临界温度 $T_c=2/\log(1+\sqrt{2})\approx 2.269185$ 发生相变。图 *13.5* 的关联函数代表高温相和低温相的定性行为。高温时，$C_L(t)$ 对系统线性尺度 L 的依赖很弱。L 增

大时，关联函数快速趋近极限曲线 $C(t)$，后者在有限时间尺度内从 *1* 降至 *0*。[5]

低温时，不存在从 *1* 降至 *0*、且使 $L \to \infty$ 时 $C_L(t) \to C(t)$ 的极限曲线。$C_L(t)$ 接近 *0* 所需的时间远大于高温相；更重要的是，它强烈依赖系统大小。这表明强协同效应导致了动力学慢化。

例 13.4. 从 $\mathcal{G}_N(2, M)$ 系综抽取随机图 G，其中 $M = N\alpha$。如将在第 *???* 章说明的，$N \to \infty$ 时，该模型在临界温度 β_c 处发生相变，后者满足 $2\alpha \tanh \beta = 1$。图 *13.6* 给出若干 N 和 $\alpha = 2$ 的数值数据，对应临界温度 $T_c \approx 3.915230$。[6]

这些曲线代表高、低温相的行为。和上例一样，低温时弛豫时间尺度强烈依赖系统大小。

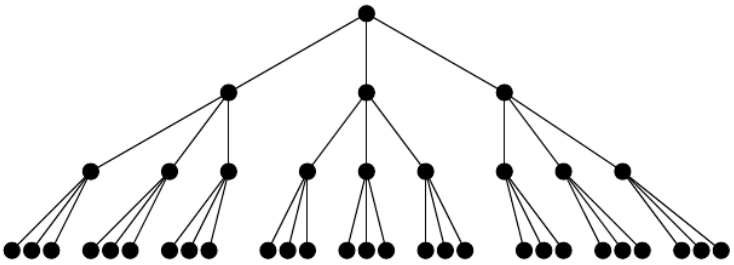


图 13.7: 有 $n = 4$ 代、$N = 40$ 个顶点的有根三叉树。

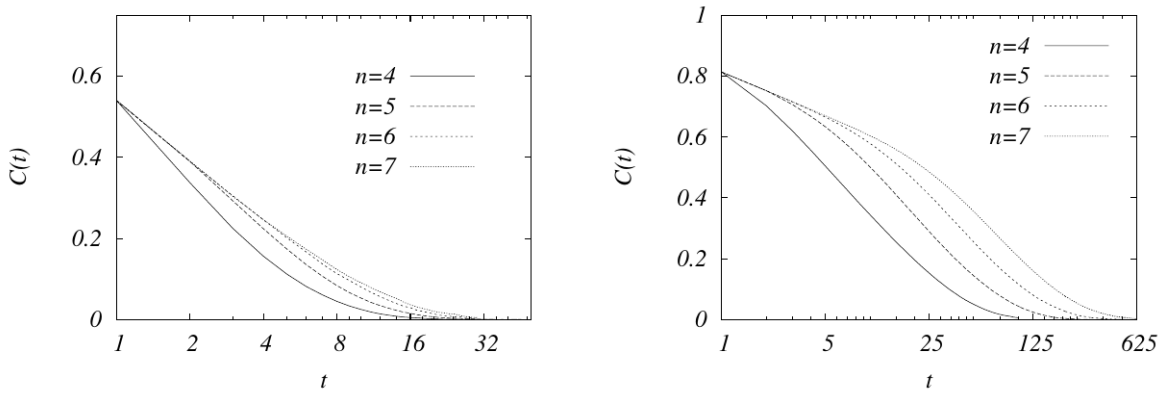


图 13.8: 正则三叉树上铁磁 Ising 模型的平衡关联函数。左：高温 $T = 2$。右：低温 $T = 1.25$。

例 13.5. 取 G 为有 n 代的有根三叉树，见图 *13.7*。它有 $N = (3^n - 1)/(3 - 1)$ 个顶点和 $N - 1$ 条边。如将在第 *???* 章看到的，该模型在满足 $3(\tanh \beta)^2 = 1$ 的临界温度 β_c 处发生相变，因此 $T_c \approx 1.528651$。这里自旋的动力学强烈依赖其到根的距离，特别是叶自旋受到的约束远少于其他自旋。为挑出“体”行为，我们修改式 (13.15)，仅对前 $\underline{n} = 3$ 代中的自旋 σ_i 取平均，并在 $n \to \infty$ 时保持 $\underline{n}$ 不变。[7]

与前例一样，高温相的 $C_N(t)$ 有良好的 $n \to \infty$ 极限，低温时则强烈依赖系统大小。

[5]译注：原稿此处有脚注 42 标记，但冻结源页及该页内容流未见相应脚注正文；保留这一来源缺口，不补造。

[6]译注：原稿章号未定，并在这里将逆温度 β_c 称作温度；保留原记号。

[7]译注：树的总代数 n 与固定取样代数 $\underline{n}$ 不同，后者在极限中保持不变。原章号仍待定；所给树上阈值与根部关联的取极限方式应在后续相应章节一并核查。

将上述三例低温相的弛豫时间尺度与系统大小关系作一比较。定义这种尺度的简单方法，是寻找 $C(t)$ 降到给定阈值以下的最早时刻：

$$\tau(\delta; N) = \min\{t > 0 \text{ 使得 } C_N(t) \le \delta\}. \tag{13.16}$$

图 13.9 使用 $\delta = 0.2$、只取低温铁磁相数据，从前例得到时间估计。$\tau(\delta; N)$ 对系统大小的依赖十分清楚，但随机图和方格网格、特别是前者的依赖，远强于树。事实上可证明，在铁磁相中

$$\tau(\delta; N) = \begin{cases} \exp\{\Theta(N)\}, & \text{随机图,} \\ \exp\{\Theta(\sqrt{N})\}, & \text{方格晶格,} \\ \exp\{\Theta(\log N)\}, & \text{树.} \end{cases} \tag{13.17}$$

第 13.3 节解释这些不同行为的来源。

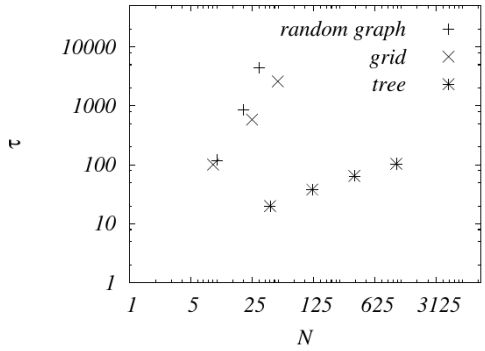


图 13.9: 低温相铁磁 Ising 模型的弛豫时间对系统大小的依赖。不同符号代表例 13.3 至例 13.5 中的不同图族。

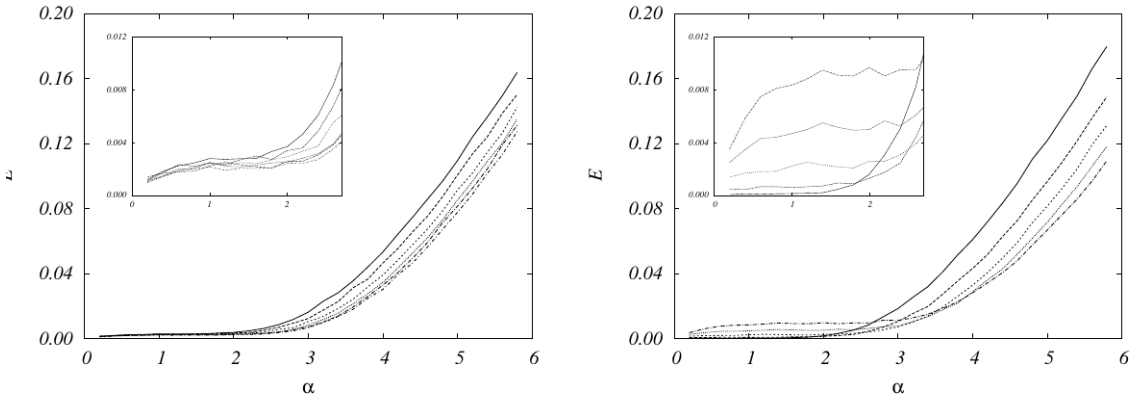


图 13.10: 用 Glauber 动力学最小化随机 3-SAT 公式的未满足子句数，固定 $N = 1000$。左：$T = 0.25$，曲线从上到下为 $L = 2.5\cdot10^3, 5\cdot10^3, 10^4, 2\cdot10^4, 4\cdot10^4, 8\cdot10^4$ 次迭代。右：$L = 4\cdot10^4$，大 α 时从上到下为 $T = 0.15, 0.20, 0.25, 0.30, 0.35$。插图放大了小 α 区域。

13.2.3 MAX-SAT

给定含 N 个布尔变量 $(x_1,\dots,x_N)=x$、$x_i\in\{0,1\}$ 的可满足性公式，MAX-SAT 优化问题要求找到使尽可能多子句成立的真值赋值。记 x_a 为第 a 个子句中的变量集，$E_a(x_a)$ 为该子句满足时取 0、否则取 2 的真值赋值函数。如此，MAX-SAT 便是最小化 $E(x)=\sum_a E_a(x_a)$，可采用式 (13.6) 后的一般方法。

考虑 Boltzmann 分布 $p_\beta(x)=\exp[-\beta E(x)]/Z$，在足够大的 β 下用 MCMC 采样。均匀随机初始化 $x\in\{0,1\}^N$。每个时间步均匀随机选指标 i，按热浴规则翻转相应变量：

$$w_i(x)=\frac{p_\beta(x^{(i)})}{p_\beta(x)+p_\beta(x^{(i)})}. \tag{13.18}$$

$x^{(i)}$ 仍为翻转第 i 个变量所得赋值。算法在 LN 步、即 L 次扫描后停止，存储当前赋值 x^* 及代价 $E^*=E(x^*)$。

图 13.10 给出此算法用于 $\mathrm{SAT}_N(3,M)$ 系综随机 3-SAT、$\alpha=M/N$ 时的结果，关注返回赋值的平均代价 $\langle E^*\rangle$。预期固定 L、令 $N\to\infty$ 时，$\langle E^*\rangle=\Theta(N)$，而 E^* 偏离均值达 N 量级的涨落概率指数地小。足够低温时，行为极度依赖 α：小 α 下，E^*/N 较小，随 α 增长缓慢，并似乎随 β 增大而趋零。这一策略基本成功，找到了近乎满足的赋值。超过 $\alpha\approx 2$–3 后，E^*/N 随 α 增长更快，且没有随 $\beta\to\infty$ 消失的迹象。扫描数 L 增大时的行为更为显著。小 α 下，E^*/N 很快降至大致不依赖 L 的饱和值，约 10^3 次扫描后即达到；大 α 下似乎也有渐近值，但接近得慢得多，即使经过 10^5 次扫描仍有改善余地。

13.3 自由能垒

这些例子表明，Monte Carlo 算法产生近似统计独立构型所需的时间尺度，随具体问题可能相差悬殊。从任意初态出发，产生近似服从平衡分布的构型所需的时间也同样如此。

有多种复杂技术可解析估计这些时间尺度，至少对没有阻挫的问题如此。本节讨论统计物理和概率论中都广泛使用的简单论证：自由能垒。基本直觉可由简单例子说明。

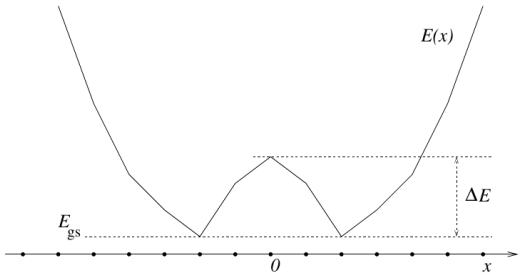


图 13.11: 双阱能量景观中的随机游走。经过多少步后，游走者会近似服从平衡分布?

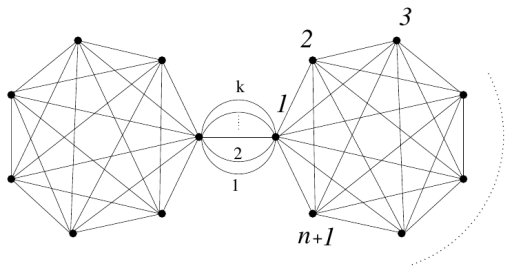


图 13.12: 随机游走探索这一图需要多久?

例 13.6. 粒子在整数线上移动，位置 $x \in \mathbb{Z}$。每点关联能量 $E(x) \geq E_{\rm gs}$，如图 *13.11*。每步以概率 1/2 选择尝试向左或向右移动。记目标位置为 x'，按 *Metropolis* 规则接受移动：

$$w(x \to x') = \min\{e^{-\beta[E(x')-E(x)]}, 1\}. \tag{13.19}$$

平衡分布当然由 *Boltzmann* 定律 $P_\beta(x) = \exp[-\beta E(x)]/Z(\beta)$ 给出。

例如从 $x = 10$ 出发，需要等多少步才使 x 服从 P_β？直观上，为达到平衡，粒子必须在左右两个阱各停留一段时间，因此必须访问 $x = 0$。平衡时，访问该点的平均时间比例为 $P_\beta(0)$。所以，为看到一次跳跃，需等待约

$$\tau \approx \frac{1}{P_\beta(0)} \tag{13.20}$$

步。

常关注 τ 的低温极限。假设 $|x| \to \infty$ 时 $E(x)$ 发散足够快，则 Z 的主导指数行为为 $Z(\beta) \doteq e^{-\beta E_{\rm gs}}$，因而 $\tau \doteq \exp\{\beta \Delta E\}$，其中 $\Delta E = E(0) - E_{\rm gs}$ 是从一个阱跨入另一个阱的能垒。这种 $\tau \doteq \exp\{\beta\Delta E\}$ 型的低温渐近式称为 Arrhenius 定律。

译注： 平稳概率的倒数直接控制平稳条件下相应集合的回返尺度，一般初态的到达、阱间转换与全局平衡时间并不自动等同。这里保留原直观估计，后文以明确的弛豫时间和瓶颈界进一步表述。

习题 13.2. 考虑图 *13.12* 的随机游走：两个各有 $n+1$ 个顶点的团，由一条 k 重简并边连接。每步从相邻边中均匀选择一条，经它移动到下一节点。平稳分布 $P_{\rm eq}(x)$、$x \in \{1, \ldots, 2n\}$ 是什么？证明位于节点 *1* 的概率为 $\frac{1}{2}\frac{k+n-1}{n^2+k-n}$。

假设游走者初态服从 $P_{\rm eq}$。用类似上例的论证，估计需要等待多少步 τ，才能得到近似独立的 x。证明 $n \gg k$ 时 $\tau \simeq 2n$，并解释结果。此时连接两团的 k 重边称为瓶颈，并称存在熵垒。

译注（原题疑点）： 团大小 $n+1$ 与状态数 $2n$、所列平稳概率的计数不一致。并且到达连接顶点后，选中跨团边的概率还依赖 k 与顶点度；单凭该点平稳概率的倒数，不能直接认证所给全局去相关时间 $2n$。原题与图照录。

为精确表述上述直觉，必须定义“弛豫时间”。考虑有限状态空间 $\mathcal{X}$ 上的遍历连续时间 Markov 链，由转移率 $w(x \to y)$ 描述。若 t 时刻处于 $x(t) = x \in \mathcal{X}$，则对任意 $y \neq x$，紧接 t 之后处于 y 的概率为

$$\mathbb{P}\{x(t+dt) = y \mid x(t) = x\} = w(x \to y)dt. \tag{13.21}$$

习题 13.3. 修改离散时间 *Markov* 链：不再在连续两步之间等待单位时间 Δt，而等待指数分布的随机时间，即 Δt 的概率密度为 $p(\Delta t) = \exp(-\Delta t)$。证明所得过程是连续时间 *Markov* 链。其转移率是什么？

令 $x \mapsto O(x)$ 为可观测量，即状态的函数，简记 $O(t) = O(x(t))$，假设 $x(0)$ 从平稳分布抽取。⋆如果链满足细致平衡，[8] 可以证明关联函数 $C_O(t) = \langle O(0)O(t)\rangle - \langle O(0)\rangle\langle O(t)\rangle$ 非负、单调下降，且 $t \to \infty$ 时趋零。定义可观测量的指数自相关时间 $\tau_{O,\exp}$ 为

$$\frac{1}{\tau_{O,\exp}} = -\lim_{t\to\infty} \frac{1}{t} \log C_O(t). \tag{13.22}$$

它依赖可观测量，描述自相关衰减到 0 的快慢：$C_O(t) \sim \exp(-t/\tau_{O,\exp})$。有意义的是寻找 “最慢” 的可观测量，并将 Markov 链的指数自相关时间、亦称逆谱隙或简称弛豫时间，定义为

$$\tau_{\exp} = \sup_O \{\tau_{O,\exp}\}. \tag{13.23}$$

译注： 上述对数定义要求可观测量具有非零平稳方差；常数可观测量的关联函数恒为 0，须在取上确界时排除或另行约定。原文未明说这一条件。

瓶颈与弛豫时间的关系由以下定理阐明。

定理 13.7. 考虑状态空间为 $\mathcal{X}$ 的遍历连续时间 *Markov* 链，转移率 $\{w(x \to y)\}$ 关于平稳分布 $P(x)$ 满足细致平衡。给定两个不相交状态集 $A, B \subset \mathcal{X}$，定义其间概率流 $W(A \to B) = \sum_{x\in A, y\in B} P(x)w(x \to y)$。则

$$\tau_{\exp} \geq \frac{P(x \in A)P(x \notin A)}{W(A \to \mathcal{X} \setminus A)}. \tag{13.24}$$

换言之，通过寻找 Markov 链的瓶颈、即将构型空间划分为两个子集，可以构造关联时间的下界。如果每个子集在平衡下都具有相当大的概率，而从一边跳往另一边的概率很低，下界就会很好、Markov 链就会很慢。

例 13.8. 考虑图 *13.11* 的双阱景观随机游走，将它限制在大区间 $[-M : M]$，以使状态空间有限。取 $A = \{x \geq 0\}$，应用定理 *13.7*。有 $W(A \to \mathcal{X} \setminus A) = P_\beta(0)/2$，且由对称性 $P_\beta(x \in A) = \frac{1}{2}(1 + P_\beta(0))$。式 (13.24) 给出

$$\tau_{\exp} \geq \frac{1 - P_\beta(0)^2}{2P_\beta(0)}. \tag{13.25}$$

低温展开右侧，得到 $\tau_{\exp} \geq 2e^{\beta\Delta E}(1 + \Theta(e^{-c\beta}))$。

译注： 末式固定前因子 2 不能仅由此前的主导指数等价推出，还取决于基态简并度等；这里保留原式，不据指数阶估计认证该前因子。

习题 13.4. 将定理 *13.7* 用于图 *13.13* 的非对称双阱随机游走。*Arrhenius* 定律 $\tau_{\exp} \sim \exp(\beta\Delta E)$ 是否适用？相关能垒 ΔE 是什么？

[8] 连续时间 Markov 链关于平稳分布 $P(x)$ 满足细致平衡、或称可逆，是指任意 $x \neq y$ 都有 $P(x)w(x \to y) = P(y)w(y \to x)$。

习题 13.5. 应用定理 *13.7*，估计习题 *13.2* 图上的随机游走弛豫时间。

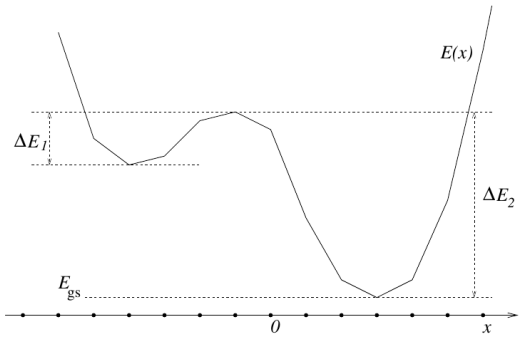


图 13.13: 非对称双阱中的随机游走。

例 13.9. 考虑例 *13.3* 中周期边界条件二维 $L\times L$ 网格上 *Ising* 模型的 *Glauber* 动力学。在铁磁相，总磁化 $M(\sigma)\equiv\sum_i\sigma_i$、$N=L^2$ 的分布集中在 $\pm NM_+(\beta)$ 附近，其中 $M_+(\beta)$ 为自发磁化强度。自然预期瓶颈对应总磁化变号。例如假设 L 为奇数，定义

$$A=\{\sigma : M(\sigma)\geq 1\},\qquad \bar{A}=\mathcal{X}\setminus A=\{\sigma : M(\sigma)\leq -1\}. \tag{13.26}$$

利用自旋翻转对称性，定理 *13.7* 给出

$$\tau_{\exp}\geq 4\sum_{\sigma:M(\sigma)=1}\sum_{i:\sigma_i=1}P_\beta(\sigma)w(\sigma\to\sigma^{(i)}). \tag{13.27}$$

注意，任意 σ 均满足 $w(\sigma\to\sigma^{(i)})\geq w(\beta)\equiv\frac{1}{2}(1-\tanh 4\beta)$，由此可很好地估计此和。另外，对和中的每个 σ，恰有 $(L^2+1)/2$ 个顶点满足 $\sigma_i=+1$。所以得到 $\tau_{\exp}\geq 2L^2w(\beta)\sum_{\sigma:M(\sigma)=1}P_\beta(\sigma)$。定义受限自由能可使这一下界的写法更直观：

$$F_L(m;\beta)\equiv -\frac{1}{\beta}\log\left\{\sum_{\sigma:M(\sigma)=m}\exp[-\beta E(\sigma)]\right\}. \tag{13.28}$$

记通常的无约束自由能为 $F_L(\beta)$，下界可写成

$$\tau_{\exp}\geq 2L^2w(\beta)\exp\{\beta[F_L(1;\beta)-F_L(\beta)]\}. \tag{13.29}$$

除指数前因子外，此式与 *Arrhenius* 定律同形，只是将能垒 ΔE 换成自由能垒 $\Delta F_L(\beta)\equiv F_L(1;\beta)-F_L(\beta)$。

译注（原推导疑点）： 式 (13.27) 按原稿保留，但对称性给出的 $P(A)P(\bar{A})=1/4$ 代入式 (13.24) 后应使概率流位于分母，原稿却写为其 4 倍。其后用转移率下界的方向、$(L^2+1)/2$ 到 $L^2/2$ 的替换，以及式 (13.29) 的前因子和指数符号之间，也未形成一致推导。这里定位疑点而不自行重写作者证明；后述自由能垒结果不能据该几行就称为本项目已验证的严格结论。

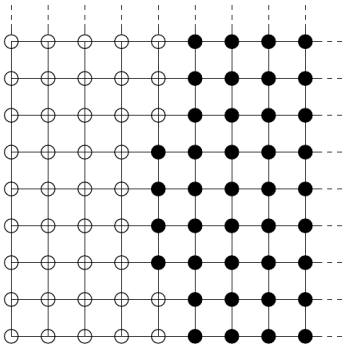


图 13.14: 周期边界条件 9×9 网格上的铁磁 Ising 模型。空心圆为 $\sigma_i=+1$，实心圆为 $\sigma_i=-1$。图示构型能量 $E(\sigma)=-122$、磁化强度 $M(\sigma)=+1$。

还需估计 $\Delta F_L(\beta)$。先考虑 $\beta\to\infty$：此时 $F_L(\beta)$ 由全正、全负构型主导，它们的能量为 $E_{\mathrm{gs}}=-2L^2$。类似地，$F_L(1;\beta)$ 由满足 $M(\sigma)=1$ 的最低能量构型主导。图 13.14 给出一个例子，其能量为 $E(\sigma)=-2L^2+2(2L+2)$。对它作平移、旋转或自旋翻转得到的所有构型，当然具有相同能量。于是 $\Delta F_L(\beta)=2(2L+2)+\Theta(1/\beta)$。

合理的猜测是，且可以严格证明，整个低温相中 $\Delta F_L(\beta)$ 随大小的依赖保持不变：

$$\Delta F_L(\beta)\simeq 2\gamma(\beta)L, \tag{13.30}$$

其中表面张力 $\gamma(\beta)$ 对任意 $\beta>\beta_c$ 严格为正，且在 $\beta\downarrow\beta_c$ 时趋零。这又给出关联时间的下界

$$\tau_{\exp}\geq \exp\{2\beta\gamma(\beta)L+o(L)\}. \tag{13.31}$$

这与前节数值模拟吻合，并可证明给出了正确的渐近大小依赖。

习题 13.6. *考虑例 13.4 所研究的 $\mathcal{G}_N(2,M)$ 随机图上的铁磁 Ising 模型，具体假设 N 为偶数。仿照上述论证，证明*

$$\tau_{\exp}\geq C_N(\beta)\exp\{\beta[F_N(0;\beta)-F_N(\beta)]\}. \tag{13.32}$$

这里 $C_N(\beta)$ 为以高概率随 N 增长慢于指数的常数，$F_N(m;\beta)$ 是限制 $M(\sigma)=m$ 后的自由能，$F_N(\beta)$ 为无约束配分函数。

对图 G，将一半顶点染红、一半染蓝，记双色边数的最小值为 $\delta(G)$。证明

$$F_N(0;\beta)-F_N(\beta)=2\delta(G_N)+\Theta(1/\beta). \tag{13.33}$$

对给定图计算 $\delta(G)$，称为平衡最小割或图划分问题，已知是 NP 完全的。对 $\mathcal{G}_N(2,M)$ 随机图，已知固定 $\alpha=M/N>1/2$、取 $N,M\to\infty$ 时，以高概率有 $\delta(G_N)=\Theta(N)$。注意，$\alpha<1/2$ 时图没有巨型分支，显然 $\delta(G)=o(N)$。

以下计算可支持这一断言。给定满足 $\sum_i\sigma_i=0$ 的自旋构型 $\sigma=(\sigma_1,\dots,\sigma_N)$，令 $\Delta_G(\sigma)$ 为 G 中满足 $\sigma_i\neq\sigma_j$ 的边 (i,j) 数。则

$$\mathbb{P}\{\delta(G)\leq n\}=\mathbb{P}\{\exists\sigma:\Delta_G(\sigma)\leq n\}\leq\sum_{m=0}^{n}\mathbb{E}N_{G,m}, \tag{13.34}$$

其中 $N_{G,m}$ 为满足 $\Delta_G(\sigma)=m$ 的自旋构型数。证明

$$\mathbb{E}N_{G,m}=\binom{N}{N/2}\binom{N}{2}^{-M}\binom{M}{m}\left(\frac{N^2}{4}\right)^{m}\left[\binom{N/2}{2}-\frac{N^2}{4}\right]^{M-m}. \tag{13.35}$$

在 $\alpha=M/N$ 固定、N,M 很大时估计此式，证明它以高概率蕴含 $\delta(G)\geq c(\alpha)N+$，其中 $\alpha>1/2$ 时 $c(\alpha)>0$。

在第*???*章，将论证 β 足够大时均有 $F_N(0;\beta)-F_N(\beta)=\Theta(N)$。

译注（原题疑点）： 源文将 $F_N(\beta)$ 称为配分函数，但上文及该差值需要自由能记号。式 (13.35) 方括号内按原图确为 $\binom{N/2}{2}-N^2/4$，对正偶数 N 为负，当 $M-m$ 为奇数时右端会给负的期望，不能是一般计数公式。源式的独立抽边式幂次与固定 M 简单图系综的关系也待核查。随后不等式末尾的 "$N+$" 是原文多出的加号，保留其未完成状态。巨型分支的出现本身也不足以推出整个 $\alpha>1/2$ 区间内的平衡最小割均为线性量级，原断言的阈值与条件仍须核查。这里不把该计算视为已经证明随机图线性能垒。

习题 13.7. 对例 *13.5* 的正则三叉树重复上述论证，推导式 (13.32) 型的界。证明低温时成立 *Arrhenius* 定律，即 $\tau_{\mathrm{exp}}\geq\exp\{\beta\Delta E_N+o(\beta)\}$。$N$ 很大时 ΔE_N 如何变化？

提示：从全正基态到全负基态构造构型序列，使任意相邻两个构型只相差一次单自旋翻转，可得到上界。

注释

Bayesian 网络的介绍见 Jordan（1998）、Jensen（1996）。Cooper 证明了 Bayesian 推断是 NP 困难的，Dagun 与 Luby 说明近似 Bayesian 推断仍为 NP 困难。另一方面，被观察变量数固定时，它变为多项式问题。[9]

通过 Glauber 动力学解码 LDPC 码，见 Franz、Leone、Montanari 与 Ricci-Tersenghi（2002）；可满足性问题见 Svenson 与 Nordahl（1999）。

Arrhenius 定律及能垒、或 "激活能" 概念，由瑞典化学家 Svante Arrhenius 于 1889 年研究化学动力学时发现。Monte Carlo Markov 链方法分析的介绍，特别是枚举问题及平衡 / 收敛速率，见 Jerrum 与 Sinclair（1996）、Sinclair（1997）。Aldous 与 Fill 筹备中的著作（Aldous 与 Fill, 2005）从概率角度完整阐述这一主题；数学物理视角可参阅 Martinelli 的讲义（Martinelli, 1999）。[10]

关于树上 Ising 模型 Glauber 动力学的早期处理，见 Henley（1986）；该文对习题 13.7 给出了部分答案。

[9]译注：最后一句按原文保留，固定观察变量数本身未说明网络、查询与近似精度等限制，不能据此将一般网络推断认证为多项式可解。人名 Dagun 按原稿保留；Part F 另列 Dagum 与 Luby（1993），拼写差异不静默消除。

[10]译注："筹备中" 等时态对应冻结 2007 年作者草稿，不代替对文献现状的核实。

第十四章　信念传播

考虑一个普遍的问题：计算图模型的边缘分布。模型有 N 个变量 $x = (x_1, \dots, x_N)$，取值于有限字母表 $\mathcal{X}$。朴素算法对所有构型求和，需要 $|\mathcal{X}|^N$ 量级的时间。底层因子图具有特殊结构时，复杂度可以大幅降低。极端情形是树因子图：计算边缘分布所需的运算次数随 N 线性增长。这可以通过一种“动态规划”过程实现：从叶节点出发，向树的“中心”推进，递归地对变量求和。

值得注意的是，这种递归过程可以改写为分布式的“消息传递”算法。消息与因子图的边关联，通过顶点处的局部计算递归更新。在树上给出精确边缘分布的更新规则，已在不同领域独立发现：统计物理中的“Bethe–Peierls 近似”、编码理论中的和积算法，以及人工智能中的信念传播（belief propagation，BP）。这里采用人工智能的术语。

容易证明，BP 在树因子图上精确计算边缘分布。但直到最近，人们才发现它在有环图上也可能极其有效。其成功的一种基本直觉是：BP 作为局部算法，在底层图“局部”为树时应当成功。这样的图经常出现，例如纠错码的因子图；BP 在这一领域十分强大。不过，即使如此，它的适用性仍限于远距离变量趋于不相关的分布。相变典型地伴随长程关联的出现，这通常使 BP 表现恶化。后续几章将展示这一思想的若干应用。

第 14.1 节用两个简单例子介绍基本思想；第 14.2 节给出一般 BP 方程及树上精确性的说明。第 14.3 节讨论可用于优化的最大积（或等价的最小和）算法。第 14.4 节讨论有环图上的 BP。研究随机约束满足问题时，BP 消息成为随机变量；其分布包含大量实例信息，并能刻画相图。分布的时间演化称为密度演化，不动点分析则是复本对称腔方法；两者见第 14.6 节。

14.1　两个例子

14.1.1　例一：Ising 链

考虑直线上的铁磁 Ising 模型。变量为自旋 $\sigma = (\sigma_1, \dots, \sigma_N)$，其中 $\sigma_i \in \{+1, -1\}$，联合分布为 Boltzmann 形式

$$p_\beta(\sigma) = \frac{1}{Z} e^{-\beta E(\sigma)}, \qquad E(\sigma) = -\sum_{i=1}^{N-1} \sigma_i \sigma_{i+1} - B \sum_{i=1}^{N} \sigma_i. \tag{14.1}$$

相应因子图见图 14.1。现在计算自旋 σ_j 的边缘概率 $p(\sigma_j)$。引入到达自旋 j 的三个“消息”，分别表示与其相连的函数节点对 $p(\sigma_j)$ 的贡献。具体地，定义

$$\widehat{\nu}_{\to j}(\sigma_j) = \frac{1}{Z_{\to j}} \sum_{\sigma_1 \cdots \sigma_{j-1}} \exp\left\{ \beta \sum_{i=1}^{j-1} \sigma_i \sigma_{i+1} + \beta B \sum_{i=1}^{j-1} \sigma_i \right\},$$
$$\widehat{\nu}_{j\leftarrow}(\sigma_j) = \frac{1}{Z_{j\leftarrow}} \sum_{\sigma_{j+1} \cdots \sigma_N} \exp\left\{ \beta \sum_{i=j+1}^{N-1} \sigma_i \sigma_{i+1} + \beta B \sum_{i=j+1}^{N} \sigma_i \right\}. \tag{14.2}$$

译注（原式疑点）：第二行相互作用求和下限在源 PDF 中为 $j+1$，因而右端不含 σ_j；与后文右链消息及分解不一致。此处照录，不静默改成 j。

消息理解为概率分布，因此要归一化。常数 $Z_{\to j}, Z_{j\leftarrow}$ 由 $\widehat{\nu}_{\to j}(+1) + \widehat{\nu}_{\to j}(-1) = 1$ 及右向的对应条件确定。后文对归一化分布不再显式写出归一化常数，以 $\cong$ 表示“相差一个归一化因子而相等”。例如第一式可写为

$$\widehat{\nu}_{\to j}(\sigma_j) \cong \sum_{\sigma_1 \cdots \sigma_{j-1}} \exp\left\{ \beta \sum_{i=1}^{j-1} \sigma_i \sigma_{i+1} + \beta B \sum_{i=1}^{j-1} \sigma_i \right\}. \tag{14.3}$$

重排对 $i \neq j$ 的自旋求和，边缘分布可写为

$$p(\sigma_j) \cong \widehat{\nu}_{\to j}(\sigma_j) e^{\beta B \sigma_j} \widehat{\nu}_{j\leftarrow}(\sigma_j). \tag{14.4}$$

三个因子分别可视为三个相邻函数节点向 j 发出的消息。每个消息都是修改后图模型中 σ_j 的边缘分布。例如，$\widehat{\nu}_{\to j}$ 对应于删除 j 附近除左侧因子外所有因子的图模型。

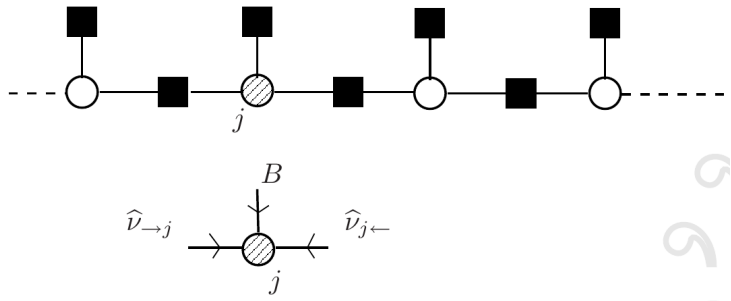


图 14.1: 上：外场中一维 Ising 模型的因子图。下：到达位置 j 的三个消息，分别描述左链 $\widehat{\nu}_{\to j}$、右链 $\widehat{\nu}_{j\leftarrow}$ 和外场 B 对 σ_j 概率分布的贡献。

这一分解的意义在于，消息可迭代计算。例如

$$\widehat{\nu}_{\to i+1}(\sigma) \cong \sum_{\sigma'} \widehat{\nu}_{\to i}(\sigma') e^{\beta \sigma' \sigma + \beta B \sigma'}. \tag{14.5}$$

而 $\widehat{\nu}_{\to 1}$ 是均匀分布，即 $\widehat{\nu}_{\to 1}(\sigma) = 1/2$。于是只需 $O(N)$ 次运算，就可计算所有 $\widehat{\nu}_{\to i}$。类似地，从均匀分布 $\widehat{\nu}_{N\leftarrow}$ 出发，递归计算 $\widehat{\nu}_{i-1\leftarrow}$。最后用式 (14.4) 在线性时间内计算全部边缘分布。

消息是二元变量上的分布，因此可用一个实数参数化。常用选择是对数似然比[1]

$$u_{\to i} \equiv \frac{1}{2\beta} \log \frac{\widehat{\nu}_{\to i}(+1)}{\widehat{\nu}_{\to i}(-1)}. \tag{14.6}$$

[1]这里的定义与统计学中标准对数似然比相差因子 $1/(2\beta)$，引入这一因子是为了与统计物理定义衔接。

统计物理中 $u_{\to i}$ 是“有效（或局部）磁场”：$\widehat{\nu}_{\to i}(\sigma) \cong e^{\beta u_{\to i}\sigma}$，也就是

$$\widehat{\nu}_{\to i}(\sigma) = \frac{1}{2}[1 + \sigma \tanh(\beta u_{\to i})].$$

式 (14.5) 化为

$$u_{\to i+1} = f(u_{\to i} + B), \tag{14.7}$$

$$f(x) = \frac{1}{\beta}\operatorname{atanh}[\tanh\beta \tanh(\beta x)]. \tag{14.8}$$

映射 $u \mapsto f(u+B)$ 可微，导数以 $\tanh\beta < 1$ 为界。因此不动点方程 $u = f(u+B)$ 有唯一解 u^*，且 $i \to \infty$ 时 $u_{\to i} \to u^*$。考虑很长的链及体内节点 $j \in [\varepsilon N, (1-\varepsilon)N]$。当 $N \to \infty$，$u_{\to j}$ 和 $u_{j\leftarrow}$ 均趋于 u^*，故 $\langle\sigma_j\rangle \to \tanh[\beta(2u^* + B)]$，这就是体磁化。边界自旋的磁化较小：$\langle\sigma_1\rangle = \langle\sigma_N\rangle \to \tanh[\beta(u^* + B)]$。**译注：**原文的有符号“较小”须限于 $\beta > 0$、$B > 0$；$B < 0$ 时边界磁化较不负，故有符号不等式反向，而绝对值仍较小；$B = 0$ 时两者相等。

习题 14.1. 利用式 (14.7) 证明，当 N, j 趋于无穷时，$\langle\sigma_j\rangle = M + O(\lambda^j, \lambda^{N-j})$，其中 $M = \tanh(2u^* + B)$、$\lambda = f'(u^* + B)$。与第 2 章一维 *Ising* 模型的处理比较。

译注：原题 M 的双曲正切自变量未含前文的 β，照录。

以上方法可推广到多个变量的联合分布。例如 $k > j$ 时，已知 $p(\sigma_j)$，只需计算 $p(\sigma_k \mid \sigma_j)$。固定 σ_j 的两个可能值后，$\sigma_{j+1}, \ldots, \sigma_N$ 的条件分布与式 (14.1) 同形，只是 σ_j 固定。因此仍可用上述算法计算条件边缘分布；唯一差别是初值：条件 $\sigma_j = +1$ 对应 $\widehat{\nu}_{\to j}(+1) = 1$、$\widehat{\nu}_{\to j}(-1) = 0$，条件 $\sigma_j = -1$ 则相反。

习题 14.2. 当 $j, k \in [N\varepsilon, N(1-\varepsilon)]$ 且 $N \to \infty$ 时，计算关联函数 $\langle\sigma_j\sigma_k\rangle$。检验 $B = 0$ 时 $\langle\sigma_j\sigma_k\rangle = (\tanh\beta)^{|j-k|}$，并寻找该结果更简单的推导。

14.1.2 例二：树奇偶校验码

第二个例子是解码问题。图 14.2 左侧给出一个简单线性码的因子图，码长 $N = 7$，码字满足三个奇偶校验方程

$$x_0 \oplus x_1 \oplus x_2 = 0, \tag{14.9}$$

$$x_0 \oplus x_3 \oplus x_4 = 0, \tag{14.10}$$

$$x_0 \oplus x_5 \oplus x_6 = 0. \tag{14.11}$$

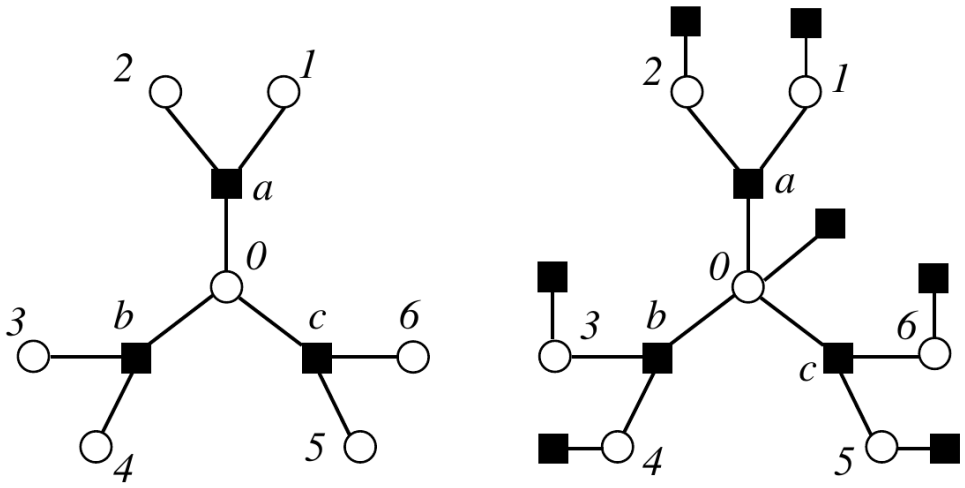


图 14.2: 左：7 个变量、3 个校验的简单奇偶校验码。右：给定接收消息后，寻找发送码字这一问题的因子图。

一个码字经过 BSC(p) 发送，假设接收消息为 $y = (1, 0, 0, 0, 0, 1, 0)$。给定 y 后，x 是发送码字的条件分布为

$$p(x \mid y) \cong \mathbb{I}(x_0 \oplus x_1 \oplus x_2 = 0)\mathbb{I}(x_0 \oplus x_3 \oplus x_4 = 0) \times \mathbb{I}(x_0 \oplus x_5 \oplus x_6 = 0) \prod_{i=0}^{6} Q(y_i \mid x_i),$$

其中 $Q(0 \mid 0) = Q(1 \mid 1) = 1 - p$、$Q(1 \mid 0) = Q(0 \mid 1) = p$，因子图见右图。

符号 MAP 解码需要每个比特的条件分布。计算本身很直接，但将它改写为类似 Ising 链的消息传递过程很有启发。考虑比特 x_0，从边界开始：若没有校验 a，x_1 的边缘分布为 $\nu_{1\to a} = (1-p, p)$。这里将二元分布写成向量 $(\nu(0), \nu(1))$；它解释为变量 1 向校验 a 发出的消息。变量 2 也向 a 发出类似消息 $\nu_{2\to a}$，本例中恰与前者相同。由两者可计算经校验 a 连到 x_0 的整条分支所作的贡献：

$$\widehat{\nu}_{a\to 0}(x_0) \cong \sum_{x_1, x_2} \mathbb{I}(x_0 \oplus x_1 \oplus x_2 = 0)\nu_{1\to a}(x_1)\nu_{2\to a}(x_2). \tag{14.12}$$

这是删除因子 b, c、擦除接收符号 y_0 后，修改图中 x_0 的边缘分布。与 Ising 链的消息类似，区别在于底层图现在是树而不再是直线，所以递推对输入消息不再线性。由此及 b, c 的类似规则得

$$\begin{aligned}
\widehat{\nu}_{a\to 0} &= (p^2 + (1-p)^2, 2p(1-p)),\\
\widehat{\nu}_{b\to 0} &= (p^2 + (1-p)^2, 2p(1-p)),\\
\widehat{\nu}_{c\to 0} &= (2p(1-p), p^2 + (1-p)^2).
\end{aligned}$$

再合并各子树及比特 x_0 的信道输出：

$$\begin{aligned}
p(x_0) &\cong Q(y_0 \mid x_0)\widehat{\nu}_{a\to 0}(x_0)\widehat{\nu}_{b\to 0}(x_0)\widehat{\nu}_{c\to 0}(x_0)\\
&\cong \big(2p^2(1-p)[p^2 + (1-p)^2]^2,\ 4p^2(1-p)^3[p^2 + (1-p)^2]\big).
\end{aligned}$$

特别地，任意 $p < 1/2$，本例中 x_0 的 MAP 符号解码总是 $x_0 = 0$。[2]这个简单计算揭示一件重要事实：无须对 $2^7 = 128$ 个构型求和，就可得到 x_0 的边缘分布；只需 6 次求和（a, b, c 各对两个 x_0 值求和），每次求和含两个加项，参见式 (14.12)。这种复杂度降低仅来自重排边缘分布计算中的加法和乘法顺序。**译注：**式 (14.12) 写为对 4 个 (x_1, x_2) 赋值求和，但奇偶约束下仅两个非零加项；上述计数按原文保留。

习题 14.3. 证明消息 $\nu_{0\to a}(x_0) = (1/2, 1/2)$，并推出 $p(x_1) \cong ((1-p)^2, p^2)$。[3]

14.2 树图上的信念传播

下面在最简单的树图模型中定义和分析 BP。在这一情形，它以高效的分布式方式解决几个计算问题。

14.2.1 三个问题

考虑其因子图为树的模型，称为树图模型。沿用第 9 章记号，N 个随机变量 $x = (x_1, \dots, x_N)$ 取值于有限字母表 $\mathcal{X}$，联合分布为

$$p(x) = \frac{1}{Z} \prod_{a=1}^{M} \psi_a(x_{\partial a}). \tag{14.13}$$

这里 $x_{\partial a} = \{x_i : i \in \partial a\}$，集合 $\partial a \subseteq [N]$ 含约束 a 涉及的全部变量，大小为 $|\partial a|$。始终以 $i, j, k, \dots$ 表示变量、$a, b, c, \dots$ 表示函数节点；∂i 含与变量 i 相连的函数节点。

当因子图无环时，以下基本问题均可用消息传递高效解决：

1. 计算单变量边缘分布 $p(x_i)$ 或少数变量的联合分布；
2. 从 $p(x)$ 采样，即产生服从该分布的独立随机构型；
3. 计算配分函数 Z，或统计物理语言中的自由熵。

BP 完成这三项任务，正是上一节过程的自然推广。

14.2.2 BP 方程

BP 是迭代消息传递算法。基本变量是因子图有向边上的消息：对边 (i, a)，第 t 次迭代有 $\nu_{i\to a}^{(t)}$、$\widehat{\nu}_{a\to i}^{(t)}$ 两个消息。消息属于单变量空间 $\mathcal{X}$ 上的概率分布空间，即 $\nu_{i\to a}^{(t)} = \{\nu_{i\to a}^{(t)}(x_i) : x_i \in \mathcal{X}\}$，且各分量非负、总和为 1。

树图模型中，消息随 $t \to \infty$ 收敛到不动点（定理 14.1），即修改后图模型的单变量边缘分布。更确切地，$\nu_{i\to a}^{(\infty)}(x_i)$ 对应删除因子 a 的模型；$\widehat{\nu}_{a\to i}^{(\infty)}(x_i)$ 对应删除 ∂i 中除 a 外所有因子的模型。

---

[2]译注：原结论照录。由原列出的两个权重直接比较，在 $0 < p < 1/2$ 时反而是 $x_0 = 1$ 的权重较大；对 7 比特码的有限穷举也得到这一点。因而这一结论与所给接收向量及公式不一致。

[3]译注：题目按源保留。将本例所给接收向量及消息代入，得到 $\nu_{0\to a} = (p, 1-p)$，并非均匀分布；故本题声称的推论也不能由该实例直接推出。

消息通过节点处的局部计算更新：节点根据上一次迭代的输入消息更新输出消息。这是各类消息传递算法的共同特点，差别在于具体更新式。BP，亦称和积算法，采用

$$\nu_{j\to a}^{(t+1)}(x_j) \cong \prod_{b\in\partial j\setminus a} \widehat{\nu}_{b\to j}^{(t)}(x_j), \tag{14.14}$$

$$\widehat{\nu}_{a\to j}^{(t)}(x_j) \cong \sum_{x_{\partial a\setminus j}} \psi_a(x_{\partial a}) \prod_{k\in\partial a\setminus j} \nu_{k\to a}^{(t)}(x_k). \tag{14.15}$$

符号 $\setminus$ 表示集合差。若 $\partial j\setminus a$ 为空，$\nu_{j\to a}$ 理解为均匀分布；若 $\partial a\setminus j$ 为空，则 $\widehat{\nu}_{a\to j}(x_j)=\psi_a(x_j)$（归一化约定仍适用）。图 14.3 示意这两条规则。不依赖于 t 且满足两式的 $2|E|$ 个消息，称为 BP 不动点；相应的 $2|E|$ 个条件也常称为 BP 方程。迭代 t 次后，对变量 i 的边缘分布估计为

$$\nu_i^{(t)}(x_i) \cong \prod_{a\in\partial i} \widehat{\nu}_{a\to i}^{(t-1)}(x_i). \tag{14.16}$$

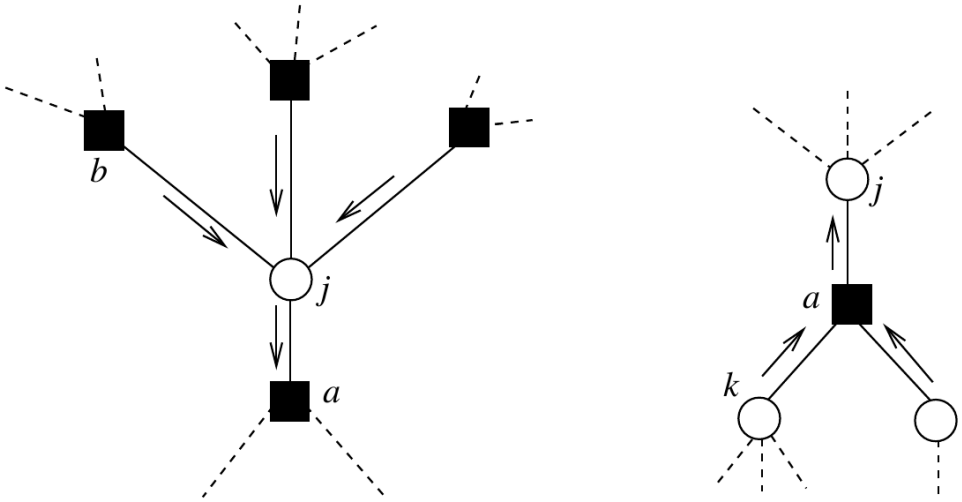


图 14.3: 左：计算 $\nu_{j\to a}^{(t+1)}$ 所涉因子图片段，输入是 $b\neq a$ 的 $\widehat{\nu}_{b\to j}^{(t)}$。右：计算 $\widehat{\nu}_{a\to j}^{(t)}$ 的图片段，输入是 $k\neq j$ 的 $\nu_{k\to a}^{(t)}$。

这里先在全部变量节点并行更新，再在全部函数节点并行更新，依此类推。因此只须在一类节点更新时增加迭代次数，不必两类都增加；式 (14.14)、(14.15) 即采用这一约定。其他调度有时也有用，这里为简单起见始终采用上述并行调度。

还须指定初值。通常将初始消息设为 $\mathcal{X}$ 上均匀分布，即 $\nu_{i\to a}^{(0)}(x_i)=1/|\mathcal{X}|$。也可探索不同的随机初值：在分布空间 $\mathcal{M}(\mathcal{X})$（原文称 $|\mathcal{X}|$ 维单纯形）上定义概率测度 P，令 $\nu_{i\to a}^{(0)}(\cdot)$ 为服从 P 的独立同分布随机变量。

在消息传递算法中，BP 由树图模型上精确计算边缘分布的性质刻画。

定理 14.1 (BP 在树上精确)**.** 考虑直径为 t_* 的树图模型，其中直径是任意两变量节点间的最大距离。则：

1. 不论初值如何，更新式 (14.14)、(14.15) 至多经过 t_* 次迭代即收敛。即任意边 (i,a) 及 $t>t_*$，$\nu_{i\to a}^{(t)}=\nu_{i\to a}^{*}$、$\widehat{\nu}_{a\to i}^{(t)}=\widehat{\nu}_{a\to i}^{*}$；

2. 不动点消息给出精确边缘分布：任意变量 i 及 $t > t_*$，$\nu_i^{(t)}(x_i) = p(x_i)$。

证明. 如前节所示，在树上 BP 只是巧妙安排构型求和的次序，从这个意义上结论显然。下面给出形式证明概要，若干细节留给读者。

给定有向边 $u \to v$，定义以它为根的子树 $T(u \to v)$：它含能通过最后一步为 $u \to v$ 的不回退路径连接到 v 的节点 w。记其深度为 $t_*(u \to v)$，即叶到 u 的最大距离。只保留该子树节点构成图模型；若 v 是函数节点则删去它，若为变量节点则保留。要证明，任意边及 $t > t_*(u \to v)$，消息 $\nu_{u\to v}^{(t)}$（若 u 为因子则为 $\widehat{\nu}_{u\to v}^{(t)}$）等于子树模型根变量的边缘分布。也就是说，树上消息作为修改边缘分布的解释是正确的。

对树深归纳。基步平凡：设 $u = i$ 为变量、$v = a$ 为因子，$T(i \to a)$ 仅含节点 i。按定义，任意 $t \geq 1$，消息为 $1/|\mathcal{X}|$，恰为该平凡模型的边缘分布。

归纳步也容易。假设深度至多 τ 时命题成立，考察深度为 $\tau+1$ 的情形。仍设 $u = i, v = a$，取 $t > \tau + 1$，由两条更新式以 $b \in \partial i \setminus a$、$j \in \partial b \setminus i$ 子树中的消息 $\nu_{j\to b}^{(t)}$ 计算 $\nu_{i\to a}^{(t+1)}$。子树 $T(j \to b)$ 深度至多 τ，由归纳假设，其消息就是根边缘分布。用更新式合并这些子树根分布，便得到 $T(i \to a)$ 根处的边缘分布，命题得证。 □

译注（适用条件）：原定理的“任意初值”按源保留；若允许零消息与硬约束，更新可能出现全零、无法归一化的退化情形。源文没有在这里补充排除条件。

14.2.3 关联与能量

BP 不限于单变量边缘分布。计算 $p(x_i, x_j)$ 时，已知 $p(x_i)$ 后只须计算 $p(x_j \mid x_i)$。给定 $x_i = x$ 的条件分布为

$$p(\boldsymbol{x} \mid x_i = x) \cong \prod_{a=1}^{M} \psi_a(x_{\partial a}) \mathbb{I}(x_i = x). \tag{14.17}$$

即在原图添加一个与 i 相连、固定其取值的度 1 函数节点。在修改图上运行 BP，就得到条件边缘估计 $\nu_j^{(t)}(x_j \mid x_i = x)$。此法易推广至 m 个变量，但需对 $|\mathcal{X}|^{m-1}$ 种赋值取条件，复杂度随变量数指数增长。

好在树图模型的多变量边缘分布可显式写成消息函数。令 F_R 为函数节点子集，V_R 为其相邻变量集合，R 为诱导子图，x_R 为对应变量。不失一般性设 R 连通。令 ∂R 为不在 F_R 中、但与 V_R 中某变量相连的函数节点集。任意 $a \in \partial R$ 与 V_R 有唯一公共变量 $i(a)$。由定理 14.1 及其中的消息解释立即得

$$p(x_R) = \frac{1}{Z_R} \prod_{a \in F_R} \psi_a(x_{\partial a}) \prod_{a \in \partial R} \widehat{\nu}^*_{a \to i(a)}(x_{i(a)}). \tag{14.18}$$

星号表示不动点消息。

习题 14.4. 将此结果用于树因子图中一条路径上的联合分布。给定变量节点 i, j，令 $R = (V_R, F_R, E_R)$ 为它们之间路径节点诱导的子图；对每个 $a \in F_R$，记路径上与之相邻的变量为 $i(a), j(a)$。证明

$$p(x_R) = \frac{1}{Z_R} \prod_{a \in F_R} \widehat{\psi}_a(x_{i(a)}, x_{j(a)}) \prod_{l \in V_R} \widehat{\psi}_l(x_l). \tag{14.19}$$

即 $p(x_R)$ 按 R 因子化。以原相容函数及发往 W 中节点的消息写出 $\widehat{\psi}_a, \widehat{\psi}_l$。

译注： 原题末尾集合 W 在此未定义，照录。

一个特别有用的例子是内能。物理问题中 $\psi_a = e^{-\beta E_a}$，β 为逆温度、E_a 为约束 a 的能量。任何图模型都可这样写（硬约束允许 $E_a = +\infty$），例如约定 $\beta = 1$；以下采用这一约定。总能量期望为

$$U = -\sum_{x} p(x) \sum_{a=1}^{M} \log \psi_a(x_{\partial a}). \tag{14.20}$$

将式 (14.18) 用于 $F_R = \{a\}$，再用式 (14.14) 将校验到变量消息的乘积写成变量到校验消息，得

$$U = -\sum_{a=1}^{M} \frac{1}{Z_a} \sum_{x_{\partial a}} \psi_a(x_{\partial a}) \log \psi_a(x_{\partial a}) \prod_{i \in \partial a} \nu^*_{i \to a}(x_j), \tag{14.21}$$

其中 $Z_a = \sum_{x_{\partial a}} \psi_a(x_{\partial a}) \prod_{i \in \partial a} \nu^*_{i \to a}(x_j)$。内能成为局域项之和，每个相容函数一项。**译注：** 原式及 Z_a 的乘积中写作 x_j，指标 j 未定义；应核对是否为 x_i，此处照录。

有环图上，式 (14.18)、(14.21) 不再精确成立，BP 也未必收敛。不过可把不动点消息换成任意 t 次迭代后的消息，将所得式子定义为相应 BP 估计：联合分布估计 $\nu^{(t)}(x_R)$ 及内能估计。

14.2.4 熵

分布 p 的熵为 $H[p] = -\sum_x p(x) \log p(x)$。树图模型中，熵同内能一样可写成局域量，这是以下分解性质的结果。记 $p_a(x_{\partial a})$ 为函数 a 所涉全部变量的边缘分布，$p_i(x_i)$ 为单变量边缘分布。

定理 14.2. *树图模型的联合分布可用局域边缘分布表示为*

$$p(x) = \prod_{a \in F} p_a(x_{\partial a}) \prod_{i \in V} p_i(x_i)^{1-|\partial i|}. \tag{14.22}$$

译注： *式 (14.22) 的负次幂及下式 (14.23) 的除法，应在各单点边缘 $p_i(x_i) > 0$ 的支持上理解。硬约束允许零边缘，例如图 14.4 中 $p_1(1) = 0$、节点 1 度为 2；原乘积此时不能直接计算为 $0 \cdot \infty$。对支持外的构型，须另按联合分布的零概率作延拓，不能把未定义乘积当作点态公式。*

证明. 对因子数 M 归纳。$M = 1$ 时各变量度均为 1，结论成立。设至多 M 个因子时成立，考察含 $M+1$ 个因子的树图 G。存在因子 a，其邻接变量除至多一个外度均为 1。记唯一度大于 1 的邻点为 i（不存在这样的点时类似处理）。再令 $x_\sim$ 为 “∂a 中不属于 $\partial a \setminus i$ 的变量” 所成向量。Markov 性质及 Bayes 法则给出

$$\begin{aligned} P(x) &= P(x_\sim) P(x \mid x_\sim) = P(x_\sim) P(x_{\partial a \setminus i} \mid x_i) \\ &= P(x_\sim) p_a(x_{\partial a}) p_i(x_i)^{-1}. \end{aligned} \tag{14.23}$$

译注： 引号内关于 $x_\sim$ 的原定义与后文删去 $\partial a \setminus i$ 后的全部剩余变量不一致，按源保留并标出。

易检验 $P(x_\sim)$ 按删去因子 a 及变量 $\partial a \setminus i$ 后的子图因子化：它是 $G \setminus a$ 中相容函数的乘积，再乘对 $x_{\partial a \setminus i}$ 求和产生的因子。缩减图中 i 的度小 1，由归纳假设

$$P(x_\sim) = \prod_{b \in F \setminus a} p_b(x_{\partial b}) \prod_{j \in V \setminus i} p_j(x_j)^{1-|\partial j|}\, p_i(x_i)^{2-|\partial i|}. \tag{14.24}$$

合并两式即得结论。 □

译注： 上式 $V \setminus i$ 按源照录；被删叶变量是否仍计入 V 的约定在原文未显式改写。

由分解立即得局域熵之和

$$\begin{aligned} H[p] = &- \sum_{a \in F} p_a(x_{\partial a}) \log p_a(x_{\partial a}) \\ &- \sum_{i \in V} (1 - |\partial i|) p_i(x_i) \log p_i(x_i). \end{aligned} \tag{14.25}$$

自由熵 $\Phi = \log Z = H[p] - U[p]$ 也有局域表达式：$\Phi = F[p]$，其中

$$\begin{aligned} F[p] = &- \sum_{a \in F} p_a(x_{\partial a}) \log \frac{p_a(x_{\partial a})}{\psi_a(x_{\partial a})} \\ &- \sum_{i \in V} (1 - |\partial i|) p_i(x_i) \log p_i(x_i). \end{aligned} \tag{14.26}$$

译注： 原式 (14.25)、(14.26) 未显式写出对 $x_{\partial a}$、x_i 的求和，照录；将它们理解为熵泛函时须作对应状态求和。

利用式 (14.18) 将局域边缘写成消息，就可把自由熵表示为不动点消息的函数。对 $2|E|$ 个消息 $\nu = \{\nu_{i\to a}, \widehat{\nu}_{a\to i}\}$，定义

$$F_*(\nu) = \sum_{a \in F} F_a(\nu) + \sum_{i \in V} F_i(\nu) - \sum_{(ia) \in E} F_{ia}(\nu), \tag{14.27}$$

$$\begin{aligned} F_a(\nu) &= \log \left[\sum_{x_{\partial a}} \psi_a(x_{\partial a}) \prod_{i \in \partial a} \nu_{i\to a}(x_i) \right], \\ F_i(\nu) &= \log \left[\sum_{x_i} \prod_{b \in \partial i} \widehat{\nu}_{b\to i}(x_i) \right], \\ F_{ai}(\nu) &= \log \left[\sum_{x_i} \nu_{i\to a}(x_i) \widehat{\nu}_{a\to i}(x_i) \right]. \end{aligned} \tag{14.28}$$

不难证明，在 BP 不动点 ν^* 处，$F_*(\nu^*) = F[p] = \Phi$，恢复正确自由熵。F_* 称为 Bethe 自由熵，乘上 $-1/\beta$ 后称 Bethe 自由能。上述结论总结如下。

定理 14.3 (Bethe 自由熵在树上精确)**.** *考虑树图模型，局域边缘为 $\{p_a, p_i\}$，BP 不动点为 $\nu^* = \{\nu^*_{i\to a}, \widehat{\nu}^*_{a\to i}\}$，则 $\Phi = \log Z = F[p] = F_*(\nu^*)$。*

这里在 F 中代入正确边缘、在 F_* 中代入不动点消息。第 14.4 节将在一般图中将它们视为所有“可能”边缘 / 消息空间上的函数。

习题 14.5. *考虑图 14.4 左侧的可满足性实例。穷举证明仅有两个满足赋值 $x = (0,1,1,1,0)$、$(0,1,1,1,1)$。用 BP 重新推导：计算解上均匀测度的熵，检验确为 $\log 2$。右图给出 BP 不动点。*

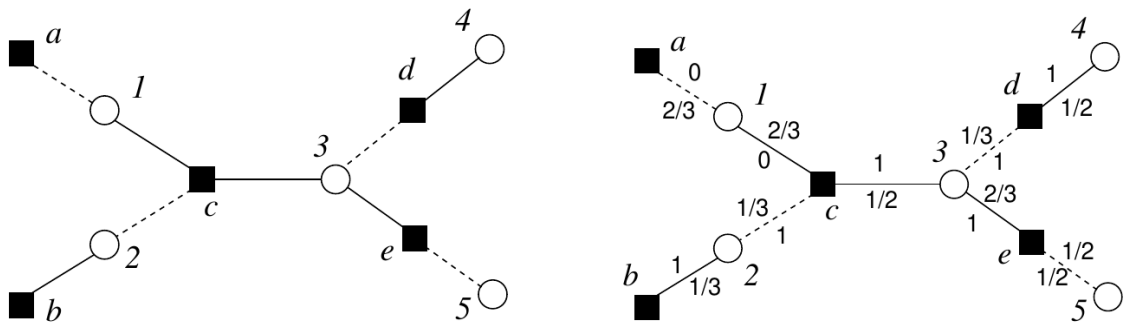


图 14.4: 左：5 变量、5 子句的可满足性实例；虚线表示变量在相邻子句中取否定。右：解上均匀测度的归一化 BP 不动点消息，显示取值 “真” 的权重。边 (a,i) 上方是 $\widehat{\nu}_{a\to i}$ 的权重，下方是 $\nu_{i\to a}$ 的权重。

习题 14.6. *许多系统含度 1 函数节点，它们相当于局部重定义 $\mathcal{X}$ 上参考测度。将这些因子单独列出，写成 $p(x)\cong\prod_{a\in F}\psi_a(x_{\partial a})\prod_{i\in V}\psi_i(x_i)$，第一类因子度至少为 2，第二类按相邻变量编号。计算 F_* 时，ψ_i 增加 N 个函数节点项，同时减去 N 个额外边项。证明两种效应抵消，净效果只是将式 (14.27) 的变量项替换为*

$$F_i(\nu)=\log\left[\sum_{x_i}\psi_i(x_i)\prod_{a\in\partial i}\widehat{\nu}_{a\to i}(x_i)\right]. \tag{14.29}$$

从高维空间 $\mathcal{X}^N$ 上的 $p(x)$ 采样，可化为计算给定部分变量后的单变量条件边缘。若有黑箱能对任意 $U\subseteq V$ 计算 $p(x_i\mid x_U)$，就能产生随机构型。标准过程称为序贯重要性采样。对树图模型，用 BP 作黑箱如下：

BP 引导采样（图模型 (G,ψ)）

1. 初始化 BP 消息；令 $U=\varnothing$。
2. 对 $t=1,\dots,N$，依次执行：运行 BP 至收敛；选择 $i\in V\setminus U$；计算 BP 边缘 $\nu_i(x_i)$；按 ν_i 抽取 x_i^*；固定 $x_i=x_i^*$，令 $U\leftarrow U\cup\{i\}$；给模型添加因子 $\mathbb{I}(x_i=x_i^*)$。
3. 返回 x^*。

14.2.5 成对模型

所有函数节点度均为 2 的图模型称为成对图模型，是重要的一类。它可表示为变量节点上的普通图 $G=(V,E)$：两个变量同为某相容函数的自变量时连边。分布为

$$p(x)=\frac{1}{Z}\prod_{(ij)\in E}\psi_{ij}(x_i,x_j). \tag{14.30}$$

函数节点可与边 (ij) 等同。此时可直接在 G 上描述 BP，并消去一类消息。只保留变量到函数的消息，简记 $\nu_{i\to j}^{(t)}(x_i)=\nu_{i\to(ij)}^{(t)}(x_i)$，更新为

$$\nu_{i\to j}^{(t+1)}(x_i)\cong\prod_{l\in\partial i\setminus j}\sum_{x_l}\psi_{il}(x_i,x_l)\nu_{l\to i}^{(t)}(x_l). \tag{14.31}$$

多变量联合分布及自由熵也有简化表达式，参见式 (14.18)、(14.27)。推导留作读者练习。 ⋆

14.3 优化：最大积与最小和

消息传递算法不限于边缘分布计算。假设给定式 (14.13) 的概率分布，要找使 $p(x)$ 最大的构型[4]。这一任务在 MAP 估计（如图像重建）到码字 MAP 解码等应用中都很重要。不难设计在树上正确解决它的消息传递算法。

14.3.1 最大边缘

这里替代边缘概率的是所谓最大边缘：

$$M_i(x_i^*) = \max_{x} \{p(x) : x_i = x_i^*\}. \tag{14.32}$$

采样及配分函数可化为边缘计算，类似地，优化可化为最大边缘计算；若有计算它的黑箱，就能高效优化。

先考察非简并情形：对每个 i，存在 x_i^*，使所有 $x_i \neq x_i^*$ 都满足严格不等式 $M_i(x_i^*) > M_i(x_i)$。则唯一最大化构型为 $(x_1^*, \dots, x_N^*)$。

一般情形可用与 BP 引导采样紧密相关的逐次固定过程。选定变量顺序 $(1, \dots, N)$，先计算 M_1，选一个最大化值 $x_1^* = \arg\max M_1(x_1)$[5]。通过添加因子 $\mathbb{I}(x_1 = x_1^*)$ 固定该变量，相当于取条件分布。计算新模型的 M_2，固定 $x_2^* = \arg\max M_2(x_2)$，依次固定全部变量，便返回一个最大化构型。

14.3.2 消息传递

只需计算最大边缘至乘法归一化因子，因此仍用 $\cong$ 表示相差整体归一化。将消息规则中的求和替换为最大化，得最大积更新式

$$\nu_{i\to a}^{(t+1)}(x_i) \cong \prod_{b\in\partial i\setminus a} \widehat{\nu}_{b\to i}^{(t)}(x_i), \tag{14.33}$$

$$\widehat{\nu}_{a\to i}^{(t)}(x_i) \cong \max_{x_{\partial a\setminus i}} \left\{ \psi_a(x_{\partial a}) \prod_{j\in\partial a\setminus i} \nu_{j\to a}^{(t)}(x_j) \right\}. \tag{14.34}$$

不动点条件也称最大积方程。若 $\partial j \setminus a$ 为空，$\nu_{j\to a} \cong 1$；若 $\partial a \setminus j$ 为空，则 $\widehat{\nu}_{a\to j} \cong \psi_a$。任意迭代次数后，最大边缘估计为

$$\nu_i^{(t)}(x_i) \cong \prod_{a\in\partial i} \widehat{\nu}_{a\to i}^{(t-1)}(x_i). \tag{14.35}$$

与 BP 一样，这些规则的主要依据来自树图模型。

定理 14.4 (最大积在树上精确)**.** *考虑直径 t_* 的树图模型。则：*

1. *不论初值如何，式 (14.33)、(14.34) 至多 t_* 次迭代收敛；任意边及 $t > t_*$，消息等于其不动点值；*

[4]满足任意 x 均有 $p(x) \le p(x^*)$ 的构型 x^* 称为分布的众数。

[5]这里及下文的 $\arg\max F(x)$ 表示全部最大化值组成的集合；写 $x^* = \arg\max F(x)$ 时，实际意指 $x^* \in \arg\max F(x)$。

2. 最大边缘估计正确：任意变量 i、$t > t_*$，$\nu_i^{(t)}(x_i) = M_i(x_i)$。

证明与定理 14.1 相近，留作练习。**译注：**原结论写作严格等号，但消息在前文仅定义至归一化，而式 (14.32) 的 M_i 一般并非和为 1。此处保留原表述；归一化因子及零消息退化条件仍需明确。

习题 14.7. 两项树上定理的关键都是求和 / 最大化对乘法的分配性质。例如 $f(x_1, x_2, x_3) = \psi_1(x_1, x_2)\psi_2(x_1, x_3)$ 时

$$\sum_{x_1,x_2,x_3} f = \sum_{x_1}\left[\left(\sum_{x_2}\psi_1(x_1,x_2)\right)\left(\sum_{x_3}\psi_2(x_1,x_3)\right)\right], \tag{14.36}$$

$$\max_{x_1,x_2,x_3} f = \max_{x_1}\left[\left(\max_{x_2}\psi_1(x_1,x_2)\right)\left(\max_{x_3}\psi_2(x_1,x_3)\right)\right]. \tag{14.37}$$

以具有分配性质的一般运算替代普通加、乘，表述一般“边缘化”问题，并描述在树上求解它的消息传递算法。

最大积消息也可解释为修改图模型的最大边缘。例如 $\nu_{i\to a}$ 是删除因子 a 后 x_i 的最大边缘估计。在树上，结合定理证明容易说明不动点消息确与这些修改模型的最大边缘一致。

寻找分布众数的等价表述，是最小化局部项之和

$$E(x) = \sum_{a\in F} E_a(x_{\partial a}). \tag{14.38}$$

以 $\psi_a = e^{-\beta E_a}$（$\beta > 0$）联系两种问题。对最大积式取对数，得到更适合能量形式的最小和算法：

$$J_{i\to a}^{(t+1)}(x_i) = \sum_{b\in\partial i\setminus a} \widehat{J}_{b\to i}^{(t)}(x_i) + C_{i\to a}^{(t)}, \tag{14.39}$$

$$\widehat{J}_{a\to i}^{(t)}(x_i) = \min_{x_{\partial a\setminus i}}\left[E_a(x_{\partial a}) + \sum_{j\in\partial a\setminus i} J_{j\to a}^{(t)}(x_j)\right] + \widehat{C}_{a\to i}^{(t)}. \tag{14.40}$$

其不动点方程在统计物理中也称能量腔方程。最大积消息只确定至乘法常数，故最小和消息只确定至加法常数。以下选择 $C, \widehat{C}$，使相应消息对 x_i 的最小值为 0。对数最大边缘估计为

$$J_i^{(t)}(x_i) = \sum_{a\in\partial i} \widehat{J}_{a\to i}^{(t-1)}(x_i) + C_i^{(t)}. \tag{14.41}$$

树上最小能量 $U_* = \min_x E(x)$ 可直接用不动点消息写为

$$U_* = \sum_a E_a(x_{\partial a}^*), \tag{14.42}$$

$$x_{\partial a}^* = \arg\min_{x_{\partial a}}\left\{E_a(x_{\partial a}) + \sum_{i\in\partial a}\widehat{J}_{i\to a}^*(x_i)\right\}. \tag{14.43}$$

译注：源式 (14.43) 的变量到因子消息带帽，与前文 $J_{i\to a}$ 记号不一致，照录；局域最小化存在简并时，任意独立选取的局域最优赋值也未必自动拼成同一全局构型。

非树图中，将不动点消息替换为 t 次迭代后的消息，便可将此视为最小能量的最大积估计 $U_*^{(t)}$。最小化构型仍可用上一小节的逐次固定过程得到。

习题 14.8. 证明还可写 $U_* = \sum_{a\in F}\epsilon_a + \sum_{i\in V}\epsilon_i - \sum_{(ia)\in E}\epsilon_{ia}$，其中

$$\epsilon_a = \min_{x_{\partial a}}\left[E_a(x_{\partial a}) + \sum_{j\in\partial a} J^*_{j\to a}(x_j)\right],$$
$$\epsilon_i = \min_{x_i}\left[\sum_{a\in\partial i}\widehat{J}^*_{a\to i}(x_i)\right], \qquad \epsilon_{ia} = \min_{x_i}[J^*_{i\to a}(x_i) + \widehat{J}^*_{a\to i}(x_i)]. \tag{14.44}$$

提示：

1. 定义 $x^*_i(a) = \arg\min[\widehat{J}^*_{a\to i}(x_i) + J^*_{i\to a}(x_i)]$，证明 $\epsilon_i, \epsilon_{ai}$ 的最小值在 $x_i = x^*_i(a)$ 取得，ϵ_a 在 $x^*_{\partial a} = \{x^*_i(a)\}_{i\in\partial a}$ 取得；
2. 证明 $\sum_{(ia)}\widehat{J}^*_{a\to i}(x^*_i(a)) = \sum_i \epsilon_i$。

译注： 习题 14.8 的提示在最小值简并时要求相容选择，不能逐边独立任取各 $\arg\min$。例如单个二元等式约束 $E_a(x_1,x_2) = \mathbf{1}\{x_1 \neq x_2\}$ 的树上，归一化不动点消息均为零；分别选 $x^*_1(a) = 0, x^*_2(a) = 1$ 虽各属边上的最小值集合，却不使因子项达到 $\epsilon_a = 0$。可从同一全局最优构型取各分量，使这些选择相容。

14.3.3 警告传播

约束满足问题中，能量只是被违反约束数：

$$E_a(x_{\partial a}) = \begin{cases} 0, & \text{约束}a \text{ 满足}, \\ 1, & \text{否则}. \end{cases} \tag{14.45}$$

这时消息结构可大为简化。若初始 $\widehat{J}^{(0)}_{a\to i}\in\{0,1\}$，最小和更新保持这一性质。归纳地，假设至 $t-1$ 成立，则变量消息 $J^{(t)}_{i\to a}$ 是非负整数。因子更新中，$J^{(t)}_{j\to a}$ 与 E_a 都是整数，所以归一化后的最小值仍是非负整数。每个邻接变量 j 都有取值 x^*_j 使 $J^{(t)}_{j\to a}(x^*_j) = 0$，故该最小值至多为 1，结论成立。**译注：** 原段文字将式 (14.39)、(14.40) 的编号互换；这里按所指运算写出，未改变论证内容。

这一论证还说明，因子最小化只依赖输入消息的哪些分量为零。如果存在各 $J^{(t)}_{j\to a}(x^*_j) = 0$，并使 $E_a(x_i, x^*_{\partial a\setminus i}) = 0$ 的赋值，最小值为 0，否则为 1。**译注：** 这里的 0 或 1 首先是归一化前的因子最小值 $m(x_i)$；实际消息还须减去 $\min_y m(y)$。例如恒违反的一元约束 $E_a(0) = E_a(1) = 1$ 给出原始输出 $(1,1)$，归一化后为 $(0,0)$。归一化后的分量仍属于 $\{0,1\}$，故先由输入零集合求值、再归一化的警告传播更新不因此失效。因此不必保留整个 $J_{i\to a}$，只需投影

$$\mathcal{J}_{i\to a}(x_i) = \min\{1, J_{i\to a}(x_i)\}. \tag{14.46}$$

命题 14.5. 考虑式 (14.38) 的优化问题，且 $E_a\in\{0,1\}$，初值 $\widehat{J}_{a\to i}(x_i)\in\{0,1\}$。任意次迭代后，函数到变量消息与以下规则算出的消息一致：

$$\mathcal{J}^{(t+1)}_{i\to a}(x_i) = \min\left\{1, \sum_{b\in\partial i\setminus a}\widehat{J}^{(t)}_{b\to i}(x_i) + C^{(t)}_{i\to a}\right\}, \tag{14.47}$$

$$\widehat{J}^{(t)}_{a\to i}(x_i) = \min_{x_{\partial a\setminus i}}\left\{E_a(x_{\partial a}) + \sum_{j\in\partial a\setminus i}\mathcal{J}^{(t)}_{j\to a}(x_j)\right\} + \widehat{C}^{(t)}_{a\to i}. \tag{14.48}$$

常数由每条消息最小值为 *0* 确定。基态能量仍由式 (14.44) 给出，只需以 $\mathcal{J}_{i\to a}$ 替换 $J_{i\to a}$。

这个简化算法称为警告传播。名称来自投影消息的解释：$\mathcal{J}_{i\to a}(x_i)=1$ 表示 “按约束 $b\in\partial i\setminus a$，变量 i 不应取 x_i”；等于 0 表示 “按这些约束，变量 i 可以取 x_i”。警告传播找出约束满足问题中部分赋值的所有直接推论；例如可满足性问题中，它找出单子句传播得到的全部推论，参见第 10 章。

14.4 有环 BP

树图模型上，消息传递能精确采样、计算边缘、配分函数和众数。大量应用需要在因子图不再是树时完成同样任务。自然可以将 BP 方程用于一般图，希望为大型模型给出近似结果。但这里多是 NP 困难问题，没有一般的性能保证。一个重要的未解挑战是寻找能回答以下问题的模型类：

1. 是否存在消息集合，通过式 (14.18) 在指定精度内重现 p 的局域边缘？
2. 这些消息是否对应更新式的近似不动点？
3. BP 更新是否至少有一个近似不动点？是否唯一？
4. 这样的不动点是否有非空吸引域？是否覆盖所有可能或 “有意义” 的初值？

一般理论尚缺，因而这里不深入回答，而描述由物理直觉、经验观测和严格证明共同形成的、相当复杂的图景。

习题 14.9. *考虑周期边界二维方格上的铁磁 Ising 模型，即包在环面上的格子，参见第 9 章：*

$$p(\sigma)=\frac{1}{Z}\exp\left\{\beta\sum_{(ij)\in E}\sigma_i\sigma_j\right\}. \tag{14.49}$$

(a) 描述对应因子图。

(b) 写出 *BP* 方程。

(c) 寻找平移不变解 $\nu_{i\to a}(\sigma_i)=\nu(\sigma_i)$、$\widehat{\nu}_{a\to i}(\sigma_i)=\widehat{\nu}(\sigma_i)$，写出两分布的方程。

(d) 用 $h=\frac{1}{2}\log[\nu(+1)/\nu(-1)]$ 参数化，证明 $\tanh(\beta h)=\tanh\beta\tanh(3\beta h)$。

(e) 研究此式，证明 $3\tanh\beta>1$ 时存在三个不同解，对应三个 *BP* 不动点。

(f) 从平移不变初值迭代 *BP*，是否收敛？收敛至哪个不动点？

(g) 将三个不动点的出现与 $p(\sigma)$ 的结构及顺磁—铁磁转变联系起来。*BP* 给出的临界温度近似值是多少？与精确值 $\beta_c=\frac{1}{2}\log(1+\sqrt{2})$ 比较。

(h) 对 d 维格子的 *Ising* 模型能得到什么结果？

译注： 原 (d) 定义的无量纲 h 与后式中的 βh 约定不一致，照录；未将一维例子的 $1/(2\beta)$ 默加到本题。此外须区别两种消息场：按本题定义，变量到因子场为 $h=\frac{1}{2}\log[\nu(+1)/\nu(-1)]$，因子到变量场为 $u=\operatorname{atanh}(\tanh\beta\tanh h)$；四邻居方格的不动点满足 $h=3u$，故应有 $\tanh(h/3)=\tanh\beta\tanh h$。若另以 $u=\beta H$ 参数化，才得到 $\tanh(\beta H)=\tanh\beta\tanh(3\beta H)$。这既涉及 β 的约定，也涉及两类消息场相差的系数 3；原题公式保留。

14.4.1 Bethe 自由熵与变分方法

树上自由熵具有局域边缘表达式。也可将它用于有环图，希望近似实际自由熵。精神上类似第 2 章的平均场自由熵，但存在若干区别。首先须定义“可能”的局域边缘空间。最基本的选择是局部相容边缘：对每个 i 给定 $\mathcal{X}$ 上分布 b_i，对每个 a 给定 $\mathcal{X}^{\partial a}$ 上分布 b_a，要求非负并归一化：

$$\sum_{x_i} b_i(x_i)=1 \quad (\forall i\in V), \qquad\qquad \sum_{x_{\partial a}} b_a(x_{\partial a})=1 \quad (\forall a\in F). \tag{14.50}$$

局部相容还要求边缘化条件

$$\sum_{x_{\partial a\setminus i}} b_a(x_{\partial a})=b_i(x_i) \quad (\forall a\in F,\ i\in\partial a). \tag{14.51}$$

其集合记为 $\mathrm{LOC}(G)$，Bethe 自由熵是其上的实值函数。任意全局分布的边缘必局部相容，反之不成立：某些局部相容边缘不可能来自任何全局分布。为强调这一点，也称它们为“信念”。

习题 14.10. *考虑图 14.5 的三二元变量模型。信念以向量 / 矩阵表示：*

$$b_i=\begin{bmatrix} b_i(0)\\ b_i(1)\end{bmatrix}, \qquad\qquad b_{ij}=\begin{bmatrix} b_{ij}(00) & b_{ij}(01)\\ b_{ij}(10) & b_{ij}(11)\end{bmatrix}. \tag{14.52}$$

检验图中信念局部相容，但不能是任何 $p(x_1,x_2,x_3)$ 的边缘。

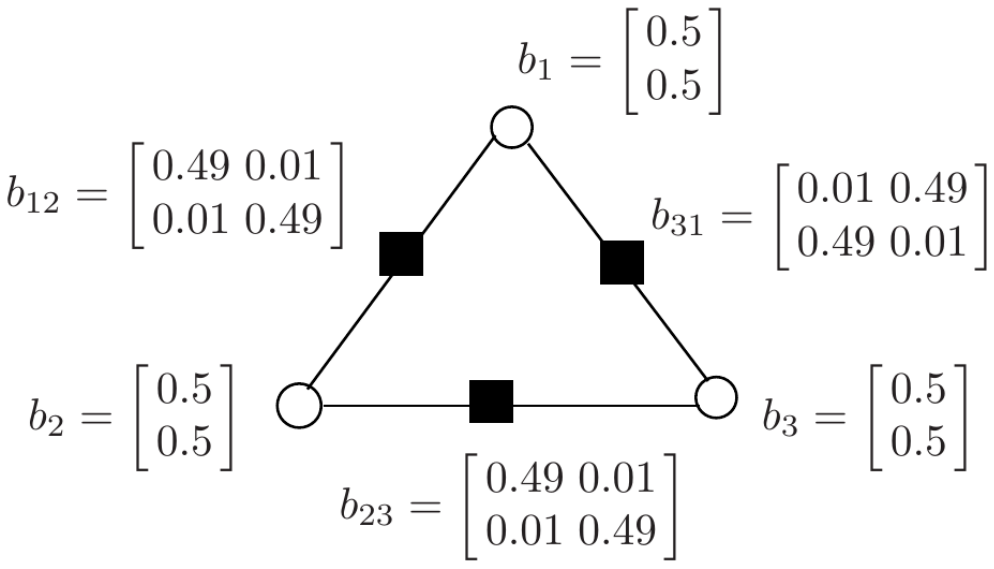


图 14.5: 一组局部相容、却不能作为任何全局分布边缘的信念。

给定 $b=\{b_a,b_i\}\in \mathrm{LOC}(G)$，仿照树上情形定义

$$F[b]=-\sum_{a\in F}b_a(x_{\partial a})\log\frac{b_a(x_{\partial a})}{\psi_a(x_{\partial a})} -\sum_{i\in V}(1-|\partial i|)b_i(x_i)\log b_i(x_i). \tag{14.53}$$

译注： 与原式 (14.26) 一样，这里状态求和未显式排出，照录。下文作为泛函变分时按相应状态求和理解。

与朴素平均场的类比提示：驻点，尤其极大值，应起重要作用。以下结果部分证实这一点。

命题 14.6. *若对每个 $a,x_{\partial a}$ 均有 $\psi_a(x_{\partial a})>0$，则 Bethe 自由熵 $F[b]$ 的驻点与 BP 不动点一一对应。*

这一对应是显式的。

证明. 在 $\mathrm{LOC}(G)$ 内变分，要满足归一化、边缘化及非负约束。引入乘子 λ_i（b_i 归一化）及 $\lambda_{ai}(x_i)$（b_a 的边缘等于 b_i），定义 Lagrange 函数

$$L(b,\lambda)=F[b]-\sum_{a\in F}\lambda_i\left[\sum_{x_i}b_i(x_i)-1\right] -\sum_{(ia),x_i}\lambda_{ai}(x_i)\left[\sum_{x_{\partial a\setminus i}}b_a(x_{\partial a})-b_i(x_i)\right]. \tag{14.54}$$

译注： 原第一项的求和指标为 $a\in F$，但被求和量用 i，照录；按所述约束应核对是否为 $i\in V$。

无须另为 b_a 归一化引入乘子，因为已由上述两类约束推出。对 b_i,b_a 的驻点条件为

$$\begin{aligned} b_i(x_i)&\cong\exp\left\{-\frac{1}{|\partial i|-1}\sum_{a\in\partial i}\lambda_{ai}(x_i)\right\},\\ b_a(x_{\partial a})&\cong\psi_a(x_{\partial a})\exp\left\{-\sum_{i\in\partial a}\lambda_{ai}(x_i)\right\}. \end{aligned} \tag{14.55}$$

乘子须使边缘化约束成立；任何这样的乘子集合给出驻点。确定 λ_{ai} 后，归一化常数便固定 λ_i。反之，每个驻点对应满足这些条件的乘子。

还须说明它们与 BP 不动点一一对应。定义

$$\begin{aligned} \nu_{i\to a}(x_i)&\cong e^{-\lambda_{ai}(x_i)},\\ \widehat{\nu}_{a\to i}(x_i)&\cong\sum_{x_{\partial a\setminus i}}\psi_a(x_{\partial a})e^{-\sum_{j\in\partial a\setminus i}\lambda_{aj}(x_j)}. \end{aligned} \tag{14.56}$$

按定义它们满足

$$\widehat{\nu}_{a\to i}(x_i)\cong\sum_{x_{\partial a\setminus i}}\psi_a(x_{\partial a})\prod_{j\in\partial a\setminus i}\nu_{i\to a}(x_i). \tag{14.57}$$

译注： 原乘积中消息的指标 / 自变量写为 i,x_i，与乘积指标 j 不一致，照录。

由式 (14.55) 第二式及消息定义，$\sum_{x_{\partial a\setminus i}} b_a \cong \nu_{i\to a}\widehat{\nu}_{a\to i}$；第一式则给出 $b_i \cong \prod_b \nu_{i\to b}^{1/(|\partial i|-1)}$。故边缘化条件意味着

$$\prod_{b\in\partial i} \nu_{i\to b}(x_i)^{1/(|\partial i|-1)} \cong \nu_{i\to a}(x_i)\widehat{\nu}_{a\to i}(x_i). \tag{14.58}$$

对 $a\in\partial i\setminus b$ 取乘积，消去 $\prod_{a\in\partial i\setminus b}\nu_{i\to a}$（正相容函数保证这一步可行），得

$$\nu_{i\to b}(x_i) \cong \prod_{a\in\partial i\setminus b} \widehat{\nu}_{a\to i}(x_i). \tag{14.59}$$

于是识别出 BP 不动点条件。反之，给定不动点，可由式 (14.56) 第一式定义乘子；不动点条件保证第二式和边缘化条件成立。 □

译注： 原中间推导含 $|\partial i|-1$ 分母，度 1 节点需要另行处理；原文未在此单列。原末尾两次引用同一更新式的编号也保留为以上文字指代，未据此补造证明。

推论 14.7. *若所有相容函数严格为正，则 BP 至少有一个不动点。*

证明. F 在闭集 $\mathrm{LOC}(G)$ 上有界连续，故在某 b^* 取得最大值。由 $\psi_a>0$，容易看出最大值在相对内部取得，即 b_a^*, b_i^* 严格为正。因此它是驻点，按命题 14.6 对应一个 BP 不动点。 □

这一变分原理与朴素平均场界类似，很有启发。实际应用有时更方便采用式 (14.27) 的消息泛函 $F_*(\nu)$，将其视为 $\mathcal{M}(\mathcal{X})^{|\vec{E}|}\to\mathbb{R}$ 的函数，$\vec{E}$ 为因子图有向边集[6]。

命题 14.8. *Bethe 自由熵 $F_*(\nu)$ 的驻点是 BP 不动点。反之，任意满足 $F_*(\nu)$ 有限的 BP 不动点也是其驻点。*

证明是简单微积分，留给读者。对于树图和单环图，原文称 $F[b]$ 是凸的，上述结果证明不动点存在且唯一；一般图中它非凸，可有多个驻点。**译注：** 这里“凸”按原句保留；前文将自由熵最大化，通常相应应讨论凹性。单环图、边界及退化条件也不能仅由本段文字自动推出唯一性，本译稿不将这一表述升级为无条件证明。

14.4.2 关联

一般有环图上 BP 误差来自何处，何时会很小？为简化记号，考虑成对图模型，推广到一般模型直接。认真采用消息的概率解释，$\nu_{i\to j}(x_i)$ 应为删除相容函数 ψ_{ij} 后的图模型中 x_i 的边缘分布，见图 14.6。记 $p_{\partial i\setminus j}(x_{\partial i\setminus j})$ 为删去全部 ψ_{il}（$l\in\partial i$）后，$\partial i\setminus j$ 各变量的联合分布，则

$$\nu_{i\to j}(x_i) \cong \sum_{x_{\partial i\setminus j}} \prod_{l\in\partial i\setminus j} \psi_{il}(x_i,x_l)\, p_{\partial i\setminus j}(x_{\partial i\setminus j}). \tag{14.60}$$

与成对 BP 式比较，若

$$p_{\partial i\setminus j}(x_{\partial i\setminus j}) = \prod_{l\in\partial i\setminus j} \nu_{l\to i}(x_l), \tag{14.61}$$

则这些消息解 BP 方程。可以将它理解为两个条件：

[6] 在树上，$F_*(\nu)$ 在变量替换意义下是 $F[b]$ 的 Lagrange 对偶。

1. 在 $p_{\partial i\setminus j}$ 下，$\{x_l : l \in \partial i \setminus j\}$ 相互独立；
2. 每个变量在此分布下的边缘等于相应消息 $\nu_{l\to i}$。即删去所有含 x_i 的相容函数，与只删去 ψ_{il}，对变量 x_l 给出相同边缘，参见图 14.7。

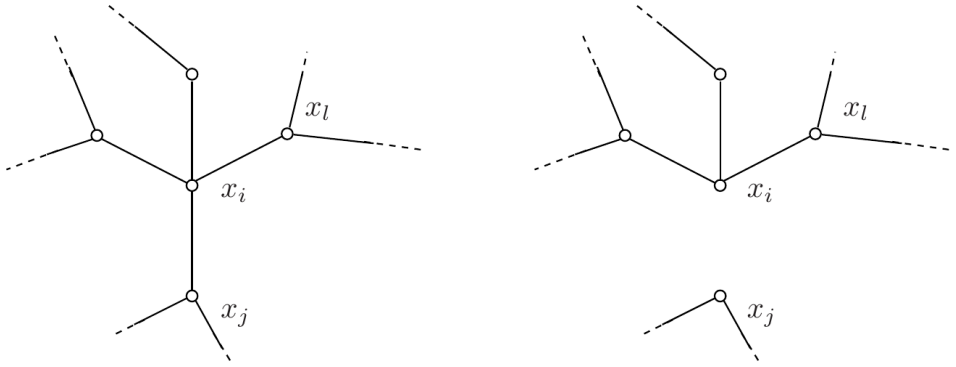


图 14.6: 成对图模型中节点 i 的邻域。右：定义消息 $\nu_{i\to j}(x_i)$ 所用的修改图模型。

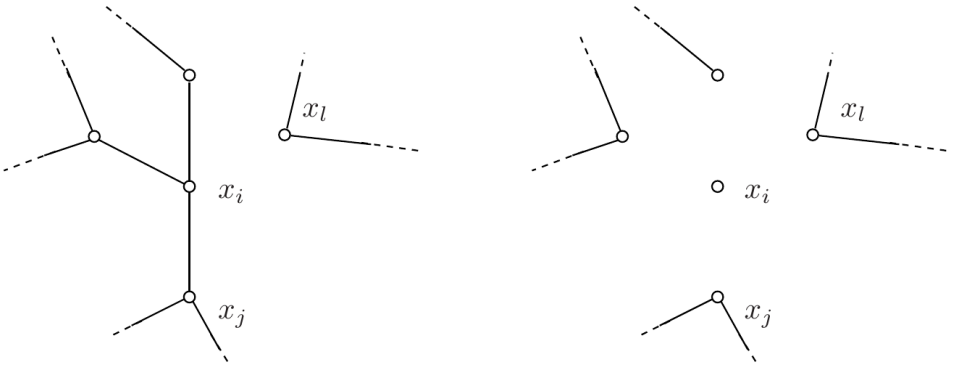


图 14.7: 左：定义 $\nu_{l\to i}(x_l)$ 的修改图模型。右：对应 i 的邻居腔分布 $p_{\partial i\setminus j}$ 的修改模型。

树上这两个条件显然成立。若腔分布下邻居变量间关联“很小”，它们也近似成立。许多实际模型（LDPC 码、随机 K-SAT 等）的因子图局部树状；删去 i 后，其邻居以高概率彼此很远。因而只要远变量关联很弱，大尺寸极限下上述两条件可能成立。下列习题作简单说明；后续章节进一步研究，并讨论条件失效时如何处理。

习题 14.11. *考虑环上反铁磁 Ising 模型，$\sigma_i \in \{+1,-1\}$，*

$$p(\sigma) = \frac{1}{Z}\exp\left\{-\beta\sum_{i=1}^{N}\sigma_i\sigma_{i+1}\right\}, \tag{14.62}$$

其中原文写 $\sigma_{N+1}\equiv\sigma_i$。这是 N 顶点环上的成对模型。

1. 写出 BP 更新规则。

2. 用对数似然 $h_{i\to}^{(t)} = \frac{1}{2}\log[\nu_{i\to i+1}^{(t)}(+1)/\nu_{i\to i+1}^{(t)}(-1)]$ 和 $h_{\leftarrow i}^{(t)} = \frac{1}{2}\log[\nu_{i\to i-1}^{(t)}(+1)/\nu_{i\to i-1}^{(t)}(-1)]$ 表示更新。

3. 证明任意 $\beta \in [0,\infty)$ 及任意初值下，*BP* 收敛到唯一不动点 $h_{\leftarrow i} = h_{i\rightarrow} = 0$。

4. 设 $\beta = +\infty$、N 为偶数。证明任意 $h_{i\rightarrow} = (-1)^i a$、$h_{\leftarrow i} = (-1)^i b$ $(a, b \in [-1,1])$ 都是不动点。

5. 设 $\beta = \infty$、N 为奇数。证明唯一不动点是全部场为 *0*，并找一个 *BP* 不收敛到该点的初值。

习题 14.12. 考虑有磁场的铁磁 *Ising* 环：

$$p(\sigma) = \frac{1}{Z} \exp\left\{ \beta \sum_{i=1}^{N} \sigma_i \sigma_{i+1} + B \sum_{i=1}^{N} \sigma_i \right\}. \tag{14.63}$$

其中原文同样写 $\sigma_{N+1} \equiv \sigma_i$；相较上一题，指数中的相互作用项改了符号。

1. 写出 *BP* 更新规则（同上一题第 *1* 项）。

2. 用对数似然表示更新（同上一题第 *2* 项）。

3. 证明任意有限 $\beta \geq 0$ 及任意初值，*BP* 收敛到唯一不动点 $h_{\leftarrow i} = h_{i\rightarrow} = h_*(\beta, B)$。

4. 设 $\langle \sigma_i \rangle$ 为真实期望、$\langle \sigma_i \rangle_{\mathrm{BP}}$ 为 *BP* 估计。证明存在 $\lambda \in (0,1)$ 使两者之差绝对值为 $O(\lambda^N)$。

译注： 两题周期边界原下标 i 不明确，通常应为 1，此处显式保留；本题外场项按原式未再乘 β。

14.5 一般消息传递算法

和积、最大积（或最小和）都是更一般消息传递算法族的成员。这些算法具有如下共同要素：

1. 消息字母表 $\mathcal{M}$，可以连续也可以离散。算法作用于因子图有向边上的消息 $\nu_{i\to a}^{(t)}, \widehat{\nu}_{a\to i}^{(t)} \in \mathcal{M}$。

2. 更新函数 $\Psi_{i\to a} : \mathcal{M}^{|\partial i \setminus a|} \to \mathcal{M}$ 及 $\Phi_{a\to i} : \mathcal{M}^{|\partial a \setminus i|} \to \mathcal{M}$。

3. 初始化，即有向边集到 $\mathcal{M}$ 的映射，也可为随机映射；像记为 $\nu_{i\to a}^{(0)}, \widehat{\nu}_{a\to i}^{(0)}$。

4. 决策规则，即从局部消息映到所关心决策空间的函数。主要关心边缘或最大边缘，因而假定决策规则为一族 $\widehat{\Psi}_i : \mathcal{M}^{|\partial i|} \to \mathcal{M}(\mathcal{X})$。

特征在于：从某节点发出的消息，只依赖经其他边到达同一节点的消息。给定这些要素，先按初始规则赋值，再对 $t \geq 0$ 并行更新：

$$\nu_{i\to a}^{(t+1)} = \Psi_{i\to a}(\{\widehat{\nu}_{b\to i}^{(t)} : b \in \partial i \setminus a\}), \tag{14.64}$$

$$\widehat{\nu}_{a\to i}^{(t)} = \Phi_{a\to i}(\{\nu_{j\to a} : j \in \partial a \setminus i\}). \tag{14.65}$$

经过预定 t 次迭代后，返回决策

$$\nu_i^{(t)}(x_i) = \widehat{\Psi}_i(\{\widehat{\nu}_{b\to i}^{(t-1)} : b \in \partial i\})(x_i). \tag{14.66}$$

译注： 式 (14.65) 输入消息在原式未写时间上标，照录。

更新调度可有许多变体。例如序贯更新每次均匀随机选择一条有向边计算消息；或随机排列边，再依此更新。不进一步讨论这些“细节”，但实际中不同调度可能有不同收敛性能。

习题 14.13. 将和积、最小和算法写成上述一般框架，给出消息字母表、更新规则及决策规则。

14.6 概率分析

后续章节将反复分析随机图模型上的消息传递。此时消息为随机变量，其分布可在大系统极限中刻画。

14.6.1 假设

先列出方法适用的技术假设。基本思想是随机图模型中不同节点应基本独立。以下设置已覆盖许多重要例子，也易推广。

随机图模型是 $x = (x_1, \dots, x_N)$ 上的随机概率分布[7]

$$p(x) \cong \prod_{a\in F} \psi_a(x_{\partial a}) \prod_{i\in V} \psi_i(x_i). \tag{14.67}$$

因子图 $G = (V, F, E)$ 与各因子 ψ_a, ψ_i 为独立随机变量。更确切地，图服从第 9 章的 $G_N(K, \alpha)$ 或 $D_N(\Lambda, P)$ 系综。对每个度 k，给定可能的因子列表 $\psi^{(k)}(x_1, \dots, x_k; \widehat{J})$，标签 $\widehat{J} \in \mathcal{J}$ 服从 $P^{(k)}$。对 $|\partial a| = k$ 的函数节点，独立抽取 $\widehat{J}_a$，令 $\psi_a = \psi^{(k)}(\cdot; \widehat{J}_a)$。类似地，单变量因子从列表 $\{\psi(\cdot; J)\}$ 按标签分布 P 抽取。图系综、标签分布及因子列表完全确定随机图模型。**译注：** 严格地，这里的因子标签是在给定图及节点度数之后，按对应度数的分布独立抽取；不能把包含随机元数的因子本身笼统说成与图无条件独立。不同度数的因子定义域不同，也不要求跨度数同分布。

再假设变量到因子的更新函数仅通过 $|\partial i|, J_i$ 依赖 $i \to a$，因子到变量的函数仅通过 $|\partial a|, \widehat{J}_a$ 依赖 $a \to i$。略微滥用记号，写为

$$\Psi_{i\to a}(\{\widehat{\nu}_{b\to i} : b \in \partial i \setminus a\}) = \Psi_l(\widehat{\nu}_1, \dots, \widehat{\nu}_l; J_i), \tag{14.68}$$

$$\Phi_{a\to i}(\{\nu_{j\to a} : j \in \partial a \setminus i\}) = \Phi_k(\nu_1, \dots, \nu_k; \widehat{J}_a), \tag{14.69}$$

其中 $l = |\partial i| - 1$、$k = |\partial a| - 1$，输入依次列出其他相邻边的消息。决策规则采用类似记号 $\widehat{\Psi}$。

习题 14.14. 令 $G = (V, E)$ 为 N 顶点、$M = N\alpha$ 边上的均匀随机图，λ_i 独立均匀分布于 $[0, \overline{\lambda}]$。独立集是满足任意 $i, j \in S$ 均无边 (ij) 的顶点集 $S \subseteq V$。考虑加权测度

$$p(S) = \frac{1}{Z}\mathbb{I}(S \text{ 为独立集}) \prod_{i\in S} \lambda_i. \tag{14.70}$$

[7] 单变量因子 ψ_i 也可像式 (14.13) 那样作为度 1 函数节点。单独写出使密度演化在变量与因子之间更对称，也更直接用于解码。

1. 以二元变量将它写成图模型，并定义因子图；

2. 描述计算边缘分布的 BP 算法；

3. 证明它是上述意义的随机图模型。

14.6.2 密度演化方程

在随机因子图 G 中均匀选一条边 (i,a)，考虑第 t 次迭代沿它发送的消息 $\nu_{i\to a}^{(t)}$。设初始消息独立同分布，分布不依赖 N。消息关于模型实现的分布包含大量信息；要刻画 $N\to\infty$ 时的分布。假设消息字母表及标签字母表是某固定维数 $\mathbb{R}^d$ 的子集，更新函数在通常拓扑下连续。

定义有向边 $i\to a$ 的半径 t 有向邻域 $B_{i\to a,t}(G)$：包含从 i 出发、第一步不走 (i,a)、长度至多 t 的不回退路径可达的所有变量节点，并包含仅与上述变量连接的函数节点，见图 14.8。具体考虑 $D_N(\Lambda,P)$，则 $N\to\infty$ 时邻域依分布收敛为随机树，与第 9 章无向邻域类似。树系综 $\mathcal{T}_t^{\to}(\Lambda,P)$ 定义如下：$t=0$ 仅有根变量；构造半径 $t\geq 1$ 时，先构造半径 $t-1$ 的树，对距根 $t-1$ 的每个变量 i 独立按 λ_l 抽取 l_i，接上 l_i-1 个新函数节点；再对每个新函数节点按 ρ_k 抽取 K_a，接上 K_a-1 个新变量节点。示意图有时还添加一条根边。

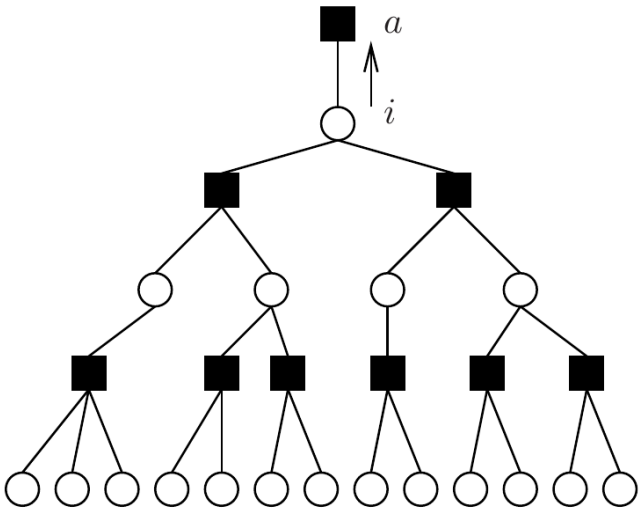


图 14.8: 半径 2 的有向邻域 $B_{i\to a,2}$。

习题 14.15. 考虑正则 $D_N(\Lambda,P)$，其中 $\Lambda_2=1,P_3=1$，即变量度 *2*、函数度 *3*。图 *14.9* 列出三种可能的半径 *1* 有向邻域。

(a) 证明给定边出现 *(B)* 或 *(C)* 邻域的概率为 $O(1/N)$。

(b) 推出 $B_{i\to a,1}\xrightarrow{d}T_1$，其中 T_1 服从 $\mathcal{T}_1^{\to}(2,3)$，即 *(A)* 中的树。

(c) 讨论半径 t 的情形。

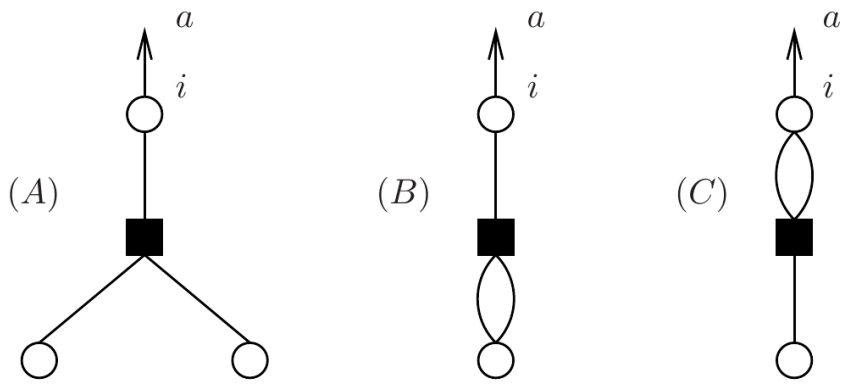


图 14.9: 正则 $D_N(2,3)$ 随机因子图中三种半径 1 有向邻域。

还须在邻域描述中包含变量标签 J_i 及函数标签 $\widehat{J}_b$。树模型也带标签：按原模型相同分布独立抽取，并独立于树。

消息 $\nu^{(t)}_{i\to a}$ 是图、标签和初始消息的函数。但它对图和标签的依赖仅通过半径 $t+1$ 的有向邻域，对初值的依赖仅通过半径 t 邻域中的 $\nu^{(0)}_{j\to b}$。暂将该邻域视为服从 $\mathcal{T}^{\rightarrow}_{t+1}$ 的随机树，定义 $\nu^{(t)}$ 为该树根边经过 t 次迭代后的消息。由邻域依分布收敛，得 $\nu^{(t)}_{i\to a}\xrightarrow{d}\nu^{(t)}$[8]。

下一步递归刻画这一极限变量。$\mathcal{T}^{\rightarrow}_{r}$ 中距根 d、朝根的边 $j\to b$ 所根植子树服从 $\mathcal{T}^{\rightarrow}_{r-d}$，因此经过 $r-d-1$ 次或更多迭代的消息服从 $\nu^{(r-d-1)}$。根变量含根边的度服从 λ_l；相邻校验的其他邻居数由 ρ_k 决定。于是得到分布方程

$$\nu^{(t+1)}\stackrel{d}{=}\Psi_l(\widehat{\nu}^{(t)}_1,\dots,\widehat{\nu}^{(t)}_l;J),\qquad\qquad \widehat{\nu}^{(t)}\stackrel{d}{=}\Phi_k(\nu^{(t)}_1,\dots,\nu^{(t)}_k;\widehat{J}). \tag{14.71}$$

这里原文说明 $\widehat{\nu}^{(t)}_b$ $(b=1,\dots,l-1)$ 是 $\widehat{\nu}^{(t)}$ 的独立副本，$\nu^{(t)}_j$ $(j=1,\dots,k-1)$ 是 $\nu^{(t)}$ 的独立副本；l,k 独立且分别服从 λ_l,ρ_k；$\widehat{J}$ 按 $P^{(k)}$、J 按 P 抽取。初始分布为初始消息的分布。**译注（原参数冲突）：** 式 (14.71) 的函数输入数为 l,k，而紧随原文的副本指标范围为 $l-1,k-1$，与前段按完整度抽样及式 (14.68)、(14.69) 按其他邻居数标记函数的约定混用。两处均照录，不能把该式直接当作无歧义可执行实现。

信息论称这些分布方程或随机变量序列为密度演化；概率组合学也称其为递归分布方程。

命题 14.9. *考虑满足本节前述假设的随机图模型，$t\ge 0$，(ia) 是均匀随机边。$N\to\infty$ 时，消息 $\nu^{(t)}_{i\to a}$、$\widehat{\nu}^{(t)}_{a\to i}$ 分别依分布收敛到密度演化式 (14.71) 所定义的 $\nu^{(t)}$、$\widehat{\nu}^{(t)}$。*

译注： 原命题引用 “假设 1–4”，但假设小节没有对应编号列表；这里只指向实际列明的条件，未补造四项新条件。**译注：** 此处极限次序是先固定任意有限迭代次数 t，再令 $N\to\infty$；有限深邻域的局部树极限并不直接涵盖 t 随 N 增长或先令 $t\to\infty$ 的情形。

后面将讨论应用。这里指出，密度演化也给出均匀随机位置决策的渐近分布。决策规则写为 $\widehat{\Phi}_i(\{\widehat{\nu}_b\})=\widehat{\Phi}_l(\widehat{\nu}_1,\dots,\widehat{\nu}_l;J_i)$，此时 $l=|\partial i|$。类似论证给出 $\mu^{(t)}_i\xrightarrow{d}\mu^{(t)}$，其中

$$\mu^{(t)}\stackrel{d}{=}\widehat{\Phi}_l(\widehat{\nu}^{(t-1)}_1,\dots,\widehat{\nu}^{(t-1)}_l;J). \tag{14.72}$$

输入消息独立同分布，J 为独立变量标签，l 按节点度分布 Λ_l 抽取。

[8]严格的读者可能会问消息空间的拓扑。原文说明：若标签分布不依赖 N，则不需要额外假设；若随 N 变化而收敛，则拓扑须使消息更新连续。

14.6.3 复本对称腔方法

统计力学的复本对称（RS）腔方法采用相近但较少算法色彩的视角：不考虑 BP 迭代，而直接研究不动点方程。基本思想是每次加一个变量，递归计算配分函数；等价地，拿出一个变量，计算配分函数变化。名称正来自在系统中挖一个 “腔” 的图像。

例如，删去原图因子 a 及其全部边；树图被分为 $|\partial a|$ 个互不连通的树。含 $j \in \partial a$ 的分量中，固定 x_j 的部分配分函数记为 $Z_{j\to a}(x_j)$，满足

$$Z_{j\to a}(x_j) = \prod_{b\in\partial j\setminus a}\left[\sum_{x_{\partial b\setminus j}} \psi_b(x_{\partial b}) \prod_{k\in\partial b\setminus j} Z_{k\to b}(x_k)\right]. \tag{14.73}$$

译注： 式 (14.73) 若用于前面单列 ψ_j 的模型，须将该单变量因子作为附着 j 的度 1 因子节点并入乘积；若仍单列，则右端还须显式乘 $\psi_j(x_j)$。例如删除唯一的因子 a 后仅剩 j 及非恒定 ψ_j 时，部分配分函数是 $\psi_j(x_j)$，而原式空乘积为 1。这里保留源式，说明其因子约定。

对一般有向边写出的这些式子，称腔方程或 Bethe 方程。它们数学上与 BP 相同，但有两个概念差别：首先自然会认为方程有不动点并赋予其特殊重要性；其次部分配分函数是未归一化消息，归一化本身也包含信息（原文指向未确定章节 “??”）。两者关系为

$$\nu_{j\to a}(x_j) = \frac{Z_{j\to a}(x_j)}{\sum_y Z_{j\to a}(y)}. \tag{14.74}$$

腔方法中的复本对称假设，是假定上述随机图模型在 $N\to\infty$ 时：

1. 腔方程有解或准解[9]；

2. 解很好地近似图模型边缘分布；

3. 解中消息的分布服从密度演化的不动点。

最后一项即归一化变量到因子消息依分布收敛到 ν，满足

$$\nu \overset{d}{=} \Psi(\widehat{\nu}_1,\dots,\widehat{\nu}_{k-1};J), \qquad \widehat{\nu} \overset{d}{=} \Phi(\nu_1,\dots,\nu_{l-1};\widehat{J}). \tag{14.75}$$

按原文沿用密度演化记号：$\widehat{\nu}_b$（$b=1,\dots,l-1$）与 ν_j（$j=1,\dots,k-1$）为独立副本，l,k 分别服从 λ,ρ，标签按对应节点分布。**译注：** 原式两组输入长度的 k,l 与随后的文字相反，仍照录；不能将这里的 RS 假设当作一般图上的既证结论。

对 Bethe 自由熵取期望，得单位变量平均值

$$F/N = F_V + aF_F - bF_E. \tag{14.76}$$

a 为单位变量的平均函数节点数，b 为单位变量平均边数。$D_N(\Lambda,P)$ 中 $a=\Lambda'(1)/P'(1), b=$

[9]准解是消息集合，其 BP 方程左右两端的平均差随 $N\to\infty$ 趋于 0。

$\Lambda'(1)$；$G_N(K,\alpha)$ 中 $a=\alpha, b=K\alpha$。三类贡献为

$$
\begin{aligned}
F_V &= \mathbb{E}_{l,J,\{\widehat{\nu}\}} \log\left[\sum_x \psi(x;J)\widehat{\nu}_1(x)\cdots\widehat{\nu}_l(x)\right],\\
F_F &= \mathbb{E}_{k,\widehat{J},\{\nu\}} \log\left[\sum_{x_1,\ldots,x_k} \psi^{(k)}(x_1,\ldots,x_k;\widehat{J})\nu_1(x_1)\cdots\nu_k(x_k)\right],\\
F_E &= \mathbb{E}_{\nu,\widehat{\nu}} \log\left[\sum_x \nu(x)\widehat{\nu}(x)\right].
\end{aligned}
\tag{14.77}
$$

期望对下标列出的随机变量取。例如 D_N 中，F_V 的 l 按 Λ、J 按 P 抽取，并取 l 个独立的 $\widehat{\nu}$ 副本。

腔方法也可计算基态能量，而非配分函数：以最小和型消息替代部分配分函数。这称为能量腔方法。单位变量平均基态能量的表达式留给读者。

14.6.4 数值方法

RS 腔方程和密度演化一般不能闭式求解，需要数值估计 $\nu,\widehat{\nu}$ 分布。这里介绍一种通用且易实现的随机方法：编码理论称采样密度演化或 Monte Carlo，统计物理称种群动力学，以下采用后一个名称。

思想是用（理想情况下）$\mathcal{N}$ 个独立同分布副本近似分布。$\mathcal{N}$ 大时，经验分布应趋于真实分布；这样的样本 $\{\nu_1,\ldots,\nu_{\mathcal{N}}\}$ 或带帽消息样本称为种群。输入为种群大小 $\mathcal{N}$、最大迭代次数 T，以及随机图模型系综的说明：边视角度分布 λ,ρ、变量标签分布 P 和因子标签分布 $P^{(k)}$。

种群动力学（模型系综，大小 $\mathcal{N}$，迭代数 T）

1. 初始化 $\{\nu_i^{(0)}\}$。
2. 对 $t=1,\ldots,T$：
   (a) 对每个 $i=1,\ldots,\mathcal{N}$，按 ρ 抽取 k；从 $\{1,\ldots,\mathcal{N}\}$ 均匀抽取 $i(1),\ldots,i(k-1)$；按 $P^{(k)}$ 抽取 $\widehat{J}$；令 $\widehat{\nu}_i^{(t)}=\Phi_k(\nu_{i(1)}^{(t-1)},\ldots,\nu_{i(k-1)}^{(t-1)};\widehat{J})$。
   (b) 对每个 $i=1,\ldots,\mathcal{N}$，按 λ 抽取 l；均匀抽取 $i(1),\ldots,i(l-1)$；按 P 抽取 J；令 $\widehat{\nu}_i^{(t)}=\Psi_l(\nu_{i(1)}^{(t)},\ldots,\nu_{i(l-1)}^{(t)};J)$。
3. 返回 $\{\nu_i^{(T)}\},\{\widehat{\nu}_i^{(T)}\}$。

译注（原伪代码疑点）：第二轮赋值左端在原文仍带帽，右端输入却不带帽；与交替更新的定义不一致。这里照录，不当作可直接执行的代码。原种群大小用花体 N，这里用 $\mathcal{N}$ 区别于图规模。

初始化时，$\nu_i^{(0)}$ 独立按 BP 初始分布抽取。固定 T，不难证明 $\mathcal{N}\to\infty$ 时两个经验分布趋于相应密度演化分布。$T\to\infty$ 更微妙。若密度演化有唯一不动点且收敛，人们期望先取 $T\to\infty$、再取 $\mathcal{N}\to\infty$ 时经验分布也趋于它。若密度演化有多个不动点，有限维种群作为 Markov 链却可能收敛到唯一不动点，似乎破坏了这些最有趣情形的应用。好在这种最终收敛的时间尺度看来随 $\mathcal{N}$ 很快增长；大种群在适中时间内会落到几个“准不动点”之一，对应密度演化的不动点。

实际可监测光滑函数 $\varphi:\mathcal{M}(\mathcal{X})\to\mathbb{R}$ 的平均

$$\langle\varphi\rangle_t=\frac{1}{\mathcal{N}}\sum_{i=1}^{\mathcal{N}}\varphi(\nu_i^{(t)}). \tag{14.78}$$

若它们在 $1/\sqrt{\mathcal{N}}$ 量级统计涨落内稳定，就视为迭代收敛的信号。这些种群可估计密度演化变量的期望；上述平均估计 $\mathbb{E}\varphi(\nu)$。若 φ 依赖 l 个独立副本，则改为

$$\langle\varphi\rangle_t=\frac{1}{R}\sum_{n=1}^{R}\varphi(\nu_{i(1)}^{(t)},\dots,\nu_{i(l)}^{(t)}). \tag{14.79}$$

其中 R 很大，通常与 $\mathcal{N}$ 同阶，每次抽样的 $i(1),\dots,i(l)$ 为独立均匀指标。只有 $l\ll\mathcal{N}$ 时估计才合理。重要应用是估计式 (14.76) 的 F_V,F_F,F_E；跨若干迭代重复计算再平均，可提高精度。**译注：**原式 (14.79) 未在指标上写出重复编号 n，按源保留；文字明确每次重复重新抽样。这里的有限种群稳定只是收敛诊断，不是一般混合时间或误差定理。

注释

BP 方程曾多次被重新发现。Pearl（1988）将它用于无环 Bayesian 网络的精确概率推断；20 世纪 60 年代初 Gallager（1963）已将其作为低密度奇偶校验码的迭代解码过程。他描述若干消息传递过程，其中包括和积算法。20 世纪 90 年代解码研究中又有多项工作重新发现基本思想，特别是 Berrou 和 Glavieux（1996）。

物理中的历史更早。Bethe（1935）使用伪边缘分布写出的自由能泛函近似铁磁 Ising 模型配分函数。由于底层模型齐次（平移不变），其方程就是习题 14.9 中讨论的简单形式。向非齐次系统推广、从而获得自然算法解释，是在 Bethe 方法用于自旋玻璃后才出现的（Thouless、Anderson 和 Palmer，1977；Klein、Schowalter 和 Shukla，1979；Katsura、Inawashiro 和 Fujiki，1979；Morita，1979；Nakanishi，1981）。

Kschischang、Frey 和 Loeliger（2001）的综述从因子图框架介绍 BP；Aji 和 McEliece（2000）强调习题 14.7 中的分配性质。树上 BP 可视为联结树算法的一个特例（Lauritzen，1996）：将某些变量分组，从原图模型构造关联树，再在树上运行 BP。

尽管早期工作已隐含这些联系，BP、Bethe 近似与和积算法的等价性直到 20 世纪 90 年代才被认识。McEliece、MacKay 和 Cheng（1998）证明 turbo 解码与和积算法均是 BP 实例；Montanari 和 Sourlas（2000）给出 turbo 解码的变分推导。Kabashima 和 Saad（1998）首先提出 BP 与 Bethe 近似等价，Yedidia、Freeman 和 Weiss（2001；2005）在更一般设置中建立它。

后一项工作特别证明了命题 14.8 的变分形式，提示可直接寻找 Bethe 自由熵驻点，而不迭代 BP。Yuille（2002）利用 Bethe 自由熵可写为凸函数与凹函数之差，提出高效过程。另一途径是构造 Bethe 自由能的凸替代物（Wainwright、Jaakkola 和 Willsky，2005b；2005a），从而定义可证明收敛的消息传递。**译注：**源文“凸函数与凹函数之差”的措辞保留。在通常共同凸定义域的意义下，这种差仍为凸函数，与前文一般图上 Bethe 自由熵可非凸的叙述存在张力。本注仅指出该数学含义；未核对 Yuille 原论文，故不擅自指定原论文实际采用的分解。

Bethe 近似还可视为变分方法层级的第一步：依次精确描述更大的变量团簇。Kikuchi（1951）最先发展这一视角，在物理中称团簇变分方法；其算法版本称广义 BP，详见 Yedidia、Freeman 和 Weiss（2005）。

随机图模型上迭代消息传递的分析可追溯至 Gallager（1963）。Richardson 和 Urbanke（2001b）结合高效数值技术将其系统化，并创造“密度演化”之名。本书视角则更接近局部弱收敛（Aldous 和 Steele，2003）。物理中，Mézard 和 Parisi（1987）首先讨论稀疏随机图模型的 RS 腔方法。种群动力学始见于 Abou-Chacra、Anderson 和 Thouless（1973），后由 Mézard 和 Parisi（2001）用于自旋玻璃；后者主要研究复本对称性破缺效应，原稿指向尚未确定的章节“??”。

第十五章　用信念传播解码

第 6 章说明，纠错码的符号 MAP 解码可视为统计推断：若 $p(x \mid y)$ 是给定信道输出 y 时输入 x 的条件分布，目标是计算单比特边缘 $p(x_i \mid y)$。采用 BP 完成这一任务十分自然。

不过，纠错码若要有良好性能，其因子图就必须有环。因此在这里 BP 只是近似推断算法。理论的主要问题是确定它何时最优，以及消息传递与最优（精确符号 MAP）解码的一般关系。本章讨论第 11 章 LDPC 系综的 BP 解码；方法可推广到其他码系综、信源编码、有记忆信道等，但这里限于理论发展最充分的典型信道编码问题。

第 15.1 节定义算法；第 15.2 节用密度演化确定可靠通信阈值，并据此优化码系综。擦除信道使问题大为简化，见第 15.3 节。第 15.4 节在大码长极限下，通过 Bethe 自由能统一理解 MAP 与 BP 解码的关系。

15.1　BP 解码算法

考虑二元输入、输出对称、无记忆信道（BMS）。发送码字 $x \in \{0,1\}^N$，输出是 N 个字母 $y_i \in \mathcal{Y} \subseteq \mathbb{R}$[1]。信道满足 $Q(y \mid 0) = Q(-y \mid 1)$。使用 LDPC 码时，条件分布为

$$p(x \mid y) = \frac{1}{Z(y)} \prod_{i=1}^{N} Q(y_i \mid x_i) \prod_{a=1}^{M} \mathbb{I}(x_{i_1^a} \oplus \cdots \oplus x_{i_{k(a)}^a} = 0). \tag{15.1}$$

因子图与码的成员函数相同：变量 x_i 出现在校验方程 a 中时，就连接变量节点 i 与校验节点 a。沿边交换消息，采用第 14 章并行调度：

$$\nu_{i\to a}^{(t+1)}(x_i) \cong Q(y_i \mid x_i) \prod_{b \in \partial i \backslash a} \widehat{\nu}_{b\to i}^{(t)}(x_i), \tag{15.2}$$

$$\widehat{\nu}_{a\to i}^{(t)}(x_i) \cong \sum_{\{x_j\}} \mathbb{I}(x_i \oplus x_{j_1} \oplus \cdots \oplus x_{j_{k-1}} = 0) \prod_{j \in \partial a \backslash i} \nu_{j\to a}^{(t)}(x_j). \tag{15.3}$$

这里 $\partial a = \{i, j_1, \ldots, j_{k-1}\}$，$\cong$ 仍表示相差归一化因子。预计渐近性能（如比特误码率）不敏感于具体调度，但有限码长性能及收敛速度可能受明显影响，本章不讨论这些问题。

时刻 t 的边缘估计，亦称信念或软判决，为

$$\mu_i^{(t)}(x_i) \cong Q(y_i \mid x_i) \prod_{b \in \partial i} \widehat{\nu}_{b\to i}^{(t-1)}(x_i). \tag{15.4}$$

据此作最优 BP 判决，亦称硬判决：

$$\widehat{x}_i^{(t)} = \arg\max_{x_i} \mu_i^{(t)}(x_i). \tag{15.5}$$

[1]一般输出字母表事实上可化归到这一情形。

还须说明初始化及何时停止。实际通常设 $\nu_{i\to a}^{(0)}(0)=\nu_{i\to a}^{(0)}(1)=1/2$；有时理论上可采用独立随机初值，如 $\nu_{i\to a}^{(0)}(0)$ 在 $[0,1]$ 上均匀。方便的停止准则是检查 $\widehat{x}^{(t)}$ 是否为码字，是则停止；否则至预定 $t_{\max}$ 停止。理论分析则固定迭代次数，即便更早得到码字也仍运行满 $t_{\max}$ 次。

消息是二元分布，可用对数似然描述（源交叉引用为 “??”）：

$$h_{i\to a}=\frac{1}{2}\log\frac{\nu_{i\to a}(0)}{\nu_{i\to a}(1)},\qquad u_{a\to i}=\frac{1}{2}\log\frac{\widehat{\nu}_{a\to i}(0)}{\widehat{\nu}_{a\to i}(1)},\tag{15.6}$$

$$B_i=\frac{1}{2}\log\frac{Q(y_i\mid 0)}{Q(y_i\mid 1)}.\tag{15.7}$$

B_i 是给定接收字母后的先验对数似然。BSC 翻转概率为 p 时，接收到 $y_i=0$ 的节点有 $B_i=\frac{1}{2}\log[(1-p)/p]$，接收到 1 则为其相反数。更新式成为

$$h_{i\to a}^{(t+1)}=B_i+\sum_{b\in\partial i\setminus a}u_{b\to i}^{(t)},\qquad u_{a\to i}^{(t)}=\operatorname{atanh}\left\{\prod_{j\in\partial a\setminus i}\tanh h_{j\to a}^{(t)}\right\}.\tag{15.8}$$

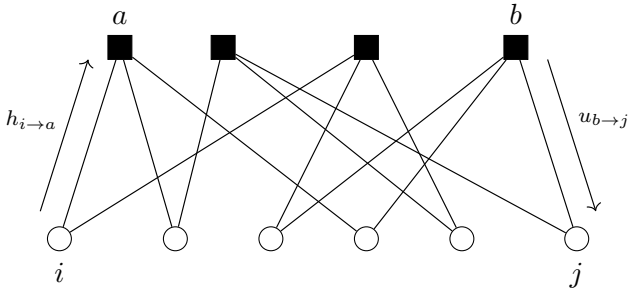


图 15.1: 正则 (2,3) LDPC 码的因子图及 BP 消息记号。

硬判决依赖总 BP 对数似然

$$h_i^{(t+1)}=B_i+\sum_{b\in\partial i\setminus a}u_{b\to i}^{(t)},\tag{15.9}$$

$$\widehat{x}_i^{(t)}(y)=\begin{cases}0, & h_i^{(t)}>0,\\ 1, & h_i^{(t)}<0,\\ 0\text{ 或}1\text{，各以概率}1/2, & h_i^{(t)}=0.\end{cases}\tag{15.10}$$

译注： 原总场式仍将 a 从邻居中排除，且未定义这里的 a；与单比特边缘所含全部输入不一致。照录原式，不暗中删去 $\setminus a$。

15.2 分析：密度演化

考虑大码长极限下随机 $\mathrm{LDPC}_N(\Lambda,P)$ 的 BP 解码。Λ_l,P_k 分别是变量与校验的节点度分布，为简单起见设 $u_{a\to i}^{(0)}=0$。由信道对称性，比特或码块错误率不依赖发送码字，其他有意义的性能指标也如此，见下一习题。因此可假设发送全零码字。先把密度演化写成第 14 章一般递推的特例。该递推可作较深入分析，尤其能证明性能随迭代改善。关键是对称性及物理退化两个性质。

习题 15.1. 发送码字 x，以 $B_i(x), u_{a\to i}^{(t)}(x), h_{i\to a}^{(t)}(x)$ 表示相应随机信道场与消息。令 $x_i = 0$ 时 $\sigma_i = +1$，否则为 -1。

(a) 证明 $\sigma_i B_i$ 的分布不依赖 x。

(b) 用更新式对 t 归纳，证明 $\{\sigma_i h_{i\to a}^{(t)}, \sigma_i u_{a\to i}^{(t)}\}$ 的联合分布不依赖 x。

(c) 用式 (15.9) 证明 $\{\sigma_i H_i^{(t)}\}$ 的分布不依赖 x，进而证明错误向量 $z^{(t)} = x \oplus \widehat{x}^{(t)}(y)$ 的分布也不依赖 x。以 $z^{(t)}$ 的分布写出比特与码块错误率。

译注：原题及后续部分结果将总场写成大写 H，前文则用小写 h；保留这一记号差异。

15.2.1 密度演化方程

固定迭代数 t，N 大时给定边的有向邻域以高概率为树，因此消息极限满足

$$h^{(t+1)} \stackrel{d}{=} B + \sum_{b=1}^{l-1} u_b^{(t)}, \qquad\qquad u^{(t)} \stackrel{d}{=} \operatorname{atanh}\left\{ \prod_{j=1}^{k-1} \tanh h_j^{(t)} \right\}. \tag{15.11}$$

输入消息是相应变量的独立副本；l, k 独立，分别服从边视角分布 λ_l, ρ_k；$B = \frac{1}{2}\log[Q(y \mid 0)/Q(y \mid 1)]$，其中 y 独立按 $Q(y \mid 0)$ 分布。初值为 $u^{(0)} = 0$。位置 i 的总场依分布趋于 $h_*^{(t)}$，其分布为

$$h_*^{(t+1)} \stackrel{d}{=} B + \sum_{b=1}^{l} u_b^{(t)}, \qquad l \sim \Lambda_l. \tag{15.12}$$

若 $P_b^{(N,t)}$ 为系综平均比特误码率，则

$$\lim_{N\to\infty} P_b^{(N,t)} = \mathbb{P}\{h_*^{(t)} < 0\} + \frac{1}{2}\mathbb{P}\{h_*^{(t)} = 0\}. \tag{15.13}$$

这一步并不平凡，因为 $\mathbb{I}(x<0) + \frac{1}{2}\mathbb{I}(x=0)$ 不连续。后面利用场分布的对称性，把误码率写成连续函数的期望以证明它。

15.2.2 基本性质一：对称性

实随机变量 Z 或其分布称为对称，如果对任意使一侧期望存在的函数 f，

$$\mathbb{E} f(-Z) = \mathbb{E}[e^{-2Z} f(Z)]. \tag{15.14}$$

若有密度 p，等价于 $p(-z) = e^{-2z}p(z)$。这一性质自然见于 BMS 信道。

命题 15.1. *BMS 信道在输入 0 条件下输出 $Y \sim Q(\cdot \mid 0)$，则 $B = \frac{1}{2}\log[Q(Y \mid 0)/Q(Y \mid 1)]$ 是对称随机变量。反之，任意对称随机变量 Z 都可作为某 BMS 信道在输入 0 条件下的对数似然比分布。*

证明. 为避免技术细节，先设输出字母表是离散实数集。由 $Q(y\mid 0)=Q(-y\mid 1)$，

$$\begin{aligned}\mathbb{E}f(-B)&=\sum_y Q(y\mid 0)f\left(\frac{1}{2}\log\frac{Q(y\mid 1)}{Q(y\mid 0)}\right)\\&=\sum_y Q(y\mid 1)f\left(\frac{1}{2}\log\frac{Q(y\mid 0)}{Q(y\mid 1)}\right)\\&=\sum_y Q(y\mid 0)\frac{Q(y\mid 1)}{Q(y\mid 0)}f\left(\frac{1}{2}\log\frac{Q(y\mid 0)}{Q(y\mid 1)}\right)\\&=\mathbb{E}[e^{-2B}f(B)].\end{aligned}\tag{15.15}$$

反之，输入 0 时输出服从 Z，输入 1 时输出服从 $-Z$，即在密度记号下

$$Q(z\mid 0)=p(z),\qquad\qquad Q(z\mid 1)=p(-z).\tag{15.16}$$

这给出所需 BMS 信道，构造并不唯一。 □

例 15.2. 对 BEC(ϵ)，输入 *0* 后，输出以概率 $1-\epsilon$ 为 *0*，以概率 ϵ 为擦除符号 $*$。B 的分布为 $(1-\epsilon)\delta_\infty+\epsilon\delta_0$，满足对称性。特别地，$\epsilon=0$ 为无噪声，$\epsilon=1$ 为完全噪声且 $P_B=\delta_0$。**译注（扩展对数似然的适用域）：** 式 (15.14) 按其定义适用于有限实值对数似然。*BEC* 或无噪声信道含 $+\infty$ 原子，须使用扩展对称测度的约定，或由有限噪声模型取极限，并明确无穷质量的记账与可用测试函数范围；不能将原式对“任意 f”的说法直接逐点延用。例如取 $f\equiv 1$ 并简单规定 $e^{-2\infty}=0$，左边为 *1*，右边却为 ϵ。这里保留源等式与 *BEC* 律，不改变其密度演化或擦除递推。

例 15.3. 对 BSC(p)，B 取 $b_0=\frac{1}{2}\log[(1-p)/p]$ 或 $-b_0$，分布为 $(1-p)\delta_{b_0}+p\delta_{-b_0}$，也对称。

例 15.4. 对二元加性白 *Gaussian* 噪声信道 BAWGN(σ^2)，输入 *0* 时输出密度为

$$q(y)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(y-1)^2}{2\sigma^2}\right\}.\tag{15.17}$$

即均值 *1*、方差 σ^2 的 *Gaussian* 分布。输入 *1* 时由对称性得均值 -1、同方差分布。给定输出 y 的对数似然为 $b=y/\sigma^2$，故

$$p(b)=\sqrt{\frac{\sigma^2}{2\pi}}\exp\left\{-\frac{\sigma^2}{2}\left(b-\frac{1}{\sigma^2}\right)^2\right\}.\tag{15.18}$$

它满足这里所定义的对称性。

密度演化变量也对称。理由是信道场对称，且 BP 运算保持对称：独立对称变量 Z_1,Z_2 的和，以及 $\operatorname{atanh}[\tanh Z_1\tanh Z_2]$ 都对称，直接验证即可。 ⋆

先考虑码因子图为树、发送全零码字、采用如 $u^{(0)}_{a\to i}=0$ 的对称初值。消息由于接收符号随机而随机；同一节点的输入来自互不相交子树，故相互独立。由更新式，全部时刻的 u,h 及总场都对称。因此：

命题 15.5. 上述条件下，若有向邻域 $B_{i\to a,t+1}$ 为树，则 $h^{(t)}_{i\to a}$ 对称；若 $B_{i,t+1}$ 为树，则 $H^{(t)}_i$ 对称。

命题 15.6. 密度演化随机变量 $h^{(t)}, u^{(t)}, H_*^{(t)}$ 对称。

习题 15.2. 利用树上对称性及固定 t 时邻域以高概率为树，证明

$$\lim_{N\to\infty} P_b^{(N,t)} = \lim_{N\to\infty} \mathbb{E}\left\{\frac{1}{N}\sum_{i=1}^{N} f(h_i^{(t)})\right\}, \tag{15.19}$$

其中 $x \le 0$ 时 $f(x) = 1/2$，否则 $f(x) = e^{-2x}/2$。

对称性是第 12 章 Nishimori 条件的推广。由该章相应式可见，条件当且仅当每个耦合的 βJ 是对称随机变量。自旋玻璃中它只在特殊温度出现，解码中却自然成立。它不仅适用于 BP 近似对数似然，也适用于真实 MAP 对数似然。

习题 15.3. 考虑真实 *MAP* 对数似然

$$h_i = \frac{1}{2}\log\frac{\mathbb{P}(x_i = 0 \mid y)}{\mathbb{P}(x_i = 1 \mid y)}. \tag{15.20}$$

在发送全零码字条件下，证明它对称：

(a) 证明 $h_i = \frac{1}{2}\log[Q(y_i \mid 0)/Q(y_i \mid 1)] + g_i$，其中 g_i 不依赖 y_i。若发送 $z \neq 0$，对应似然 $h_i(z)$ 在 $z_i = 0$ 时与 h_i 同分布，$z_i = 1$ 时与 $-h_i$ 同分布。

(b) 均匀抽取比特 z_i，再在此条件下均匀抽取码字并发送，经 *BMS* 信道得到 y，计算 $h_i(z)$。将中间过程藏入黑箱，证明 $z_i \to h_i(z)$ 是 *BMS* 信道。

(c) 推出 h_i 是对称随机变量。

15.2.3 基本性质二：物理退化

迭代增加时 BP 解码会改善，尽管未必收敛到正确值。一般推断问题中的 BP 没有这一性质。精确定义依靠物理退化：先对 BMS 信道定义，再推广至对称随机变量。

设 BMS(1)、BMS(2) 的转移概率为 Q_1, Q_2，输出字母表为 $\mathcal{Y}_1, \mathcal{Y}_2$。若存在输入 $\mathcal{Y}_1$、输出 $\mathcal{Y}_2$ 的信道 C，使 BMS(2) 统计上等价于 BMS(1) 后接 C，就称 BMS(2) 相对于 BMS(1) 物理退化。若 C 的转移概率为 R，在离散记号下

$$Q_2(y_2 \mid x) = \sum_{y_1 \in \mathcal{Y}_1} R(y_2 \mid y_1) Q_1(y_1 \mid x). \tag{15.21}$$

也即存在 Markov 链 $X \to Y_1 \to Y_2$，见图 15.2。记为 $\mathrm{BMS}(1) \preceq \mathrm{BMS}(2)$，读作前者噪声较小。它是偏序：传递性成立，双向退化时两者相等，但任意两信道不一定可比。⋆ **译注：** 原文的反对称性按源保留；若把不同输出重标记视作不同信道，双向退化通常只能推出统计等价，须在等价类上才得到严格偏序。

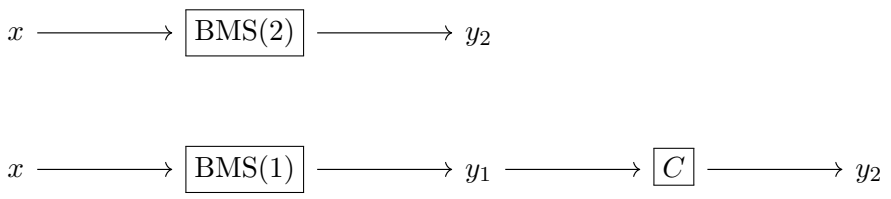


图 15.2: 上：BMS(2)。下：BMS(1) 与信道 C 串联。若两者等价，就称 BMS(2) 相对于 BMS(1) 物理退化。

例 15.7. 若 $0 \le \epsilon_1 \le \epsilon_2 \le 1$，则 $\mathrm{BEC}(\epsilon_1) \preceq \mathrm{BEC}(\epsilon_2)$。构造 C：输入 *0* 或 *1* 时，以概率 x 擦除，否则原样输出；输入擦除符号则仍输出擦除。串联擦除概率在原文写为 $\epsilon = 1-(1-x)(1-\epsilon)$。取 $x = (\epsilon_2-\epsilon_1)/(1-\epsilon_1)$ 即证（可设 $\epsilon_1 < 1$）。

译注：上式右端原写 ϵ 而非 ϵ_1，照录；所述串联概率应以第一信道参数计算。

习题 15.4. 若 $0 \le p_1 \le p_2 \le 1/2$，证明 $\mathrm{BSC}(p_1) \preceq \mathrm{BSC}(p_2)$：将后者写成前者与 $\mathrm{BSC}(x)$ 串联。x 应取多少？

习题 15.5. 若 $0 \le \sigma_1^2 \le \sigma_2^2$，证明 $\mathrm{BAWGN}(\sigma_1^2) \preceq \mathrm{BAWGN}(\sigma_2^2)$。

物理退化保持大多数信道可靠性指标的次序。例如均匀输入比特经两个信道输出 Y_1, Y_2，由数据处理不等式立即得 $H(X \mid Y_1) \le H(X \mid Y_2)$。又令 MAP 判决为 $\widehat{x}_a(y_a) = \arg\max_x \mathbb{P}(X = x \mid Y_a = y_a)$，对应错误率 $P_b^{(a)}$。把 y_1 再经 C 后作 $\widehat{x}_2$，是基于 y_1 的一种非 MAP 规则，不会优于直接对 y_1 作 MAP，故 $P_b^{(1)} \le P_b^{(2)}$。

对称变量可与 BMS 信道对应，故可推广此序：若与 Z_2 对应的信道相对于 Z_1 的信道物理退化，记为 $Z_1 \preceq Z_2$。可以证明，此定义与对应信道的具体选择无关。固定 LDPC 码，将消息视为接收向量随机性产生的变量，BP 的行为符合这种直觉。

命题 15.8. 发送全零码字，经 *BMS* 信道并以标准初值 $X = 0$ 作 *BP* 解码。若 $B_{i,r}$ 为树，则对 $t \le r-1$，$h_i^{(0)} \succeq h_i^{(1)} \succeq \cdots \succeq h_i^{(t)}$。有向邻域为树时，$h_{i\to a}^{(t)}$ 也满足相同次序。

这里只证明最有用的推论：错误率随 t 单调下降，而不证明完整物理退化结论。

证明. 全零发送下，忽略场为 0 的平局，错误率为 $\mathbb{P}(h_i^{(t)} < 0)$。树邻域中，原图的 t 次 BP 总场等于截断模型 $B_{i,t+1}$ 的真实 MAP 场。令该树定义的码为 $C_{i,t}$，均匀发送其中码字，输出为 y^t，定义

$$\widehat{h}_i^{(t)} = \frac{1}{2}\log\frac{\mathbb{P}(x_i = 0 \mid y^t)}{\mathbb{P}(x_i = 1 \mid y^t)}. \tag{15.22}$$

在 $x_i = 0$ 条件下，它与 $h_i^{(t)}$ 同分布，故相应 MAP 判错概率为 $\mathbb{P}(h_i^{(t)} < 0)$。若先擦去距 i 为 t 的接收符号，再作 MAP，剩余观测为 y^{t-1}，其对数似然就是 $t-1$ 次 BP 场。因此这一规则的判错概率为 $\mathbb{P}(h_i^{(t-1)} < 0)$。完整信息的 MAP 不劣于这一规则，结论成立。 □

随机 LDPC 图的固定半径邻域以高概率为树，所以立刻得到渐近结论。

命题 15.9. 密度演化变量满足 $h^{(0)} \succeq h^{(1)} \succeq \cdots$，$h_*^{(t)}$ 也如此。因此 $P_b^{(t)} = \lim_{N\to\infty} P_b^{(N,t)}$ 随 t 单调下降。

习题 15.6. 另一可靠性指标是条件熵。均匀发送码字时，令 $H_i(t) = H(X_i \mid h_i^{(t)})$。

(a) 证明树邻域中 $H_i(t)$ 对 $t \le r-1$ 单调下降。

(b) 若全零发送条件下 $h_i^{(t)}$ 分布为 p_t，证明 $H_i(t) = \int \log(1+e^{-2z})\, dp_t(z)$。提示：利用对称性。

15.2.4 数值实现与阈值

密度演化可以高效模拟，以估计消息及总场分布，进而得到大码长解码性能。可用固定大小样本表示分布，即第 14 章种群动力学[2]。图 15.3 给出 BSC 上两个系综的计算结果。比特错误率及条件熵均随 t 单调下降，也可证明它们随 p 单调上升。故 $P_b^{\mathrm{BP}} = \lim_{t\to\infty} P_b^{(t)}$ 存在，并随 p 不减。图中以足够大 t、数值精度内不再变化的曲线估计极限。定义 BP 阈值

$$p_d = \sup\{p \in [0,1/2] : P_b^{\mathrm{BP}}(p) = 0\}. \tag{15.23}$$

同样定义可推广至 BEC、BAWGN，或由实参数按物理退化排序的任意 BMS 信道族。

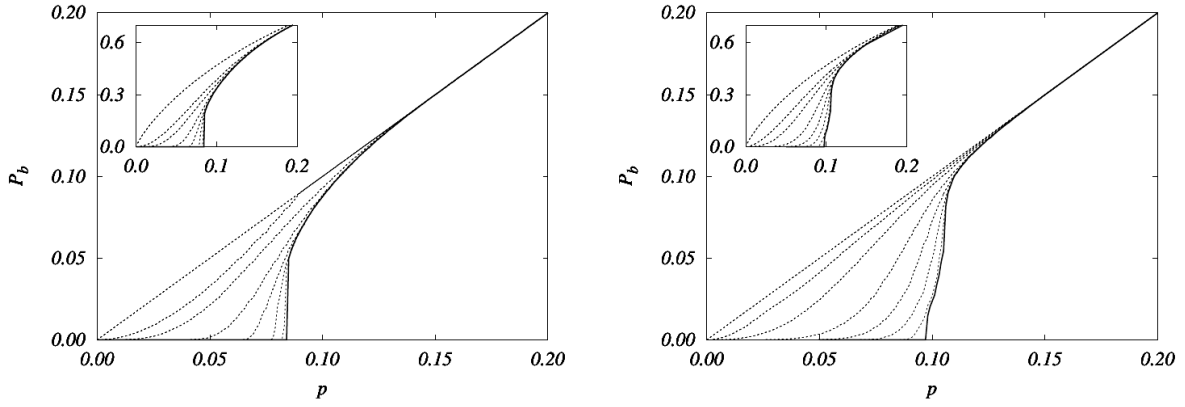


图 15.3: BSC 上两 LDPC 系综的密度演化预测，种群大小 $5\cdot 10^5$。左：(3,6) 正则系综。右：设计码率同为 1/2 的优化非正则系综，$\Lambda(x) = 0.4871x^2 + 0.3128x^3 + 0.0421x^4 + 0.1580x^{10}$，$P(x) = 0.6797x^7 + 0.3203x^8$。点线从上到下对应 $t = 1,2,3,6,11,21,51$，粗实线对应迭代极限；插图为期望条件熵。

表 15.1: 几个正则 LDPC 系综在 BSC 上的 BP 阈值，第三列为设计码率 $1 - l/k$。

l	k	R_{des}	p_d	Shannon 极限
3	4	1/4	0.1669(2)	0.2145018
3	5	2/5	0.1138(2)	0.1461024
3	6	1/2	0.0840(2)	0.1100279
4	6	1/3	0.1169(2)	0.1739524

数值密度演化可精确确定阈值。它具有实际意义：$p < p_d$ 时，随机选足够大码长的码，并运行足够多但不依赖 N 的迭代，以高概率可使比特错误率任意小。$p > p_d$ 时，任意固定迭代数的渐近错误率均不低于 $P_b^{\mathrm{BP}}(p) > 0$；实际中即使取如 N^a 次迭代通常也无助。故阈值是码性能的首要指标。

[2]另一方法将两类更新写成概率密度卷积，借助快速 Fourier 变换加速。变量侧对数似然直接给出卷积；校验侧可取 $r^{(t)} = (\operatorname{sign} h^{(t)}, \log|\tanh h^{(t)}|)$ 及 $s^{(t)} = (\operatorname{sign} u^{(t)}, \log|\tanh y^{(t)}|)$。后一个变量在原文写成 $y^{(t)}$，与该处消息记号不一致，照录。

设计好码即在给定设计码率下选择使阈值最大的度分布对。原文这里写

$$R_{\mathrm{des}} = 1 - P'(1)/\Lambda'(1).$$

一般 BMS 信道可数值优化：用密度演化计算阈值，再局部搜索度分布；BEC 则可解析优化。图中非正则系综有度 2、3、4、10 的变量与度 7、8 的校验，阈值约 0.097，而 Shannon 极限为 0.110。**译注：**以上设计码率导数比在原文与前章及表注相反，照录；图中分布按变量 / 校验节点数计数通常给出 $1 - \Lambda'(1)/P'(1)$。

该优化系综含有限比例度 2 变量。用第 11 章权枚举函数分析，其原相应参数 A 为正，低权码字很多。发送码字附近有许多码字，却仍有大 BP 阈值，颇不直观，但接近 Shannon 容量的系综往往确有差的最小距离性质，权枚举函数在短距离没有间隙。低权码字会降低有限码长阈值下性能，并使码块错误概率不能随 N 消失（每个码字中错误比特的比例为 $1/N$ 量级）；这称误码平台。

习题 15.7. 证明用其他“合理”的单比特误差指标定义阈值会给出同一结果。令 Z 对称，$P_b = \mathbb{P}(Z<0) + \frac{1}{2}\mathbb{P}(Z=0)$。证明任意 $\Delta > 0$，$\mathbb{P}(Z < \Delta) \le (2 + e^{2\Delta})P_b$。若对称变量序列 $Z^{(t)}$ 的错误率趋于 0，推出其分布趋于 $+\infty$ 处 *Dirac* 质量。

15.2.5 局部稳定性

除数值计算，还可由局部稳定性得到简单阈值解析界。信道只通过 Bhattacharyya 参数 $\mathcal{B} = \sum_y \sqrt{Q(y\mid 0)Q(y\mid 1)} \le 1$ 进入结果。它衡量噪声，并保持物理退化次序，直接计算可验证。 ⋆

稳定性还依赖度 2 比例，原文写为 $\Lambda_2 = \lambda'(0)$，以及 $\rho'(1) = \sum_k k(k-1)P_k / \sum_k kP_k$。**译注：**节点视角 Λ_2 与边视角 $\lambda'(0) = \lambda_2$ 一般不同；原句照录。

定理 15.10. 经 *Bhattacharyya* 参数为 $\mathcal{B}$ 的 *BMS* 信道通信，采用随机 $\mathrm{LDPC}_N(\Lambda, P)$ 码和任意对称初值 X 的 *BP* 解码。原文将初值称为一对 $(X(0), X(1))$。令 $P_b^{(t,N)}$ 为错误率，$P_b^{(t)}$ 为其大码长极限。

1. 若 $\lambda'(0)\rho'(1)\mathcal{B} < 1$，则存在 $\xi > 0$，若某次迭代的错误率小于 ξ，则随后趋于 0。
2. 若 $\lambda'(0)\rho'(1)\mathcal{B} > 1$，则存在 $\xi > 0$，任意 t 都有 $P_b^{(t)} > \xi$。

译注：原第 1 项在“某次”处误写“某个 ξ”；这里明确它所指的是迭代。原第 2 项与“任意对称初值”的无误差初值存在退化冲突，按原保留，不扩充适用范围。

推论 15.11. 定义局部稳定阈值

$$p_{\mathrm{loc}} = \inf\{p : \lambda'(0)\rho'(1)\mathcal{B}(p) > 1\}. \tag{15.24}$$

则有序信道族上的 *BP* 阈值满足 $p_d \le p_{\mathrm{loc}}$。

这里不完整证明，只解释稳定性论证。若变量最小度至少 2，密度演化有无误差不动点 $h, u = +\infty$。阈值是从标准初值收敛到它的最大信道参数。考察足够靠近它的初值

$$X = \begin{cases} 0, & \text{概率}\epsilon, \\ +\infty, & \text{概率}1-\epsilon. \end{cases} \tag{15.25}$$

即 BEC 对数似然分布。取 $u^{(0)} \overset{d}{=} X$，第一次变量更新为 $h^{(1)} \overset{d}{=} B + \sum_{b=1}^{l-1} X_b$，除所有 $X_b = 0$ 外均为无穷；后一情形取 B。因此

$$\text{以概率}\lambda_l: \quad h^{(1)} = \begin{cases} B, & \text{概率}\epsilon^{l-1}, \\ +\infty, & \text{概率}1-\epsilon^{l-1}. \end{cases} \tag{15.26}$$

对 ϵ 线性化得到

$$h^{(1)} = \begin{cases} B, & \text{概率}\lambda_2\epsilon + O(\epsilon^2), \\ +\infty, & \text{概率}1-\lambda_2\epsilon + O(\epsilon^2), \\ \cdots, & \text{概率}O(\epsilon^2). \end{cases} \tag{15.27}$$

最后一类本步实际上不存在，但后续迭代需用，以表示其他值的小概率。第一次校验更新中，一阶只须考虑全部输入无穷，或恰一个输入服从 B。对度平均后

$$u^{(1)} = \begin{cases} B, & \text{概率}\lambda_2\rho'(1)\epsilon + O(\epsilon^2), \\ +\infty, & \text{概率}1-\lambda_2\rho'(1)\epsilon + O(\epsilon^2), \\ \cdots, & \text{概率}O(\epsilon^2). \end{cases} \tag{15.28}$$

重复 t 次，利用 $\lambda_2 = \lambda'(0)$，原文得到

$$h^{(t)} = \begin{cases} B_1 + \cdots + B_t, & \text{概率}[\lambda'(0)\rho'(1)]^t\epsilon + O(\epsilon^2), \\ +\infty, & \text{概率}1-[\lambda'(0)\rho'(1)]^t\epsilon + O(\epsilon^2), \\ \cdots, & \text{概率}O(\epsilon^2). \end{cases} \tag{15.29}$$

错误率消失等价于 $\mathcal{P}(t;\epsilon) = \mathbb{P}(h^{(t)} \le 0)$ 趋于 0，而上式给出

$$\mathcal{P}(t;\epsilon) = \epsilon[\lambda'(0)\rho'(1)]^t \mathbb{P}(B_1 + \cdots + B_t \le 0) + O(\epsilon^2). \tag{15.30}$$

用第 4 章大偏差估计，以领先指数阶记号 $\doteq$ 写为

$$\mathbb{P}(B_1 + \cdots + B_t \le 0) \doteq \left\{ \inf_{z \ge 0} \mathbb{E}[e^{-zB}] \right\}^t. \tag{15.31}$$

由 B 对称，$\mathbb{E}e^{-zB}$ 在 $z=1$ 取最小，证明留给读者。 $\star$

$$\mathbb{P}(B_1 + \cdots + B_t \le 0) \doteq \mathcal{B}^t. \tag{15.32}$$

所以一阶系数以领先指数阶按 $[\lambda'(0)\rho'(1)\mathcal{B}]^t$ 变化，乘积小于或大于 1 决定邻近无误差不动点的收敛与否。完整证明还须控制高阶项及其他初值。**译注：** 原式将第 t 次变量场的一阶权重写成包含 t 次校验分支因子的形式，存在时间下标约定疑点；按原保留。固定 t 的 $O(\epsilon^2)$ 并不自动对 $t \to \infty$ 一致，原文也明确没有在此给完整证明。

15.3 擦除信道的 BP 解码

BEC 中，BP 有简单解释、密度演化可解析研究，并能构造达到容量的系综。

15.3.1 BP、剥离与停止集

取初值 $u_{a\to i}^{(0)}=0$。信道场在收到 0、1、擦除时分别为 $+\infty,-\infty,0$。更新使消息始终属于这三值：校验节点只要一个输入 h 为 0，输出 u 就为 0；否则输出无穷，符号为输入符号之积。变量节点若全部输入及 B_i 均为 0，则输出 0；若某个输入或 B_i 为有符号无穷，则输出同一值。变量处不会有互相矛盾的正负无穷消息。

习题 15.8. 证明若矛盾消息到达同一变量，就意味着发送消息不是码字。

消息 $+\infty$（或 $-\infty$）表示，与非擦除观测相容的全部码字都令 $x_i=0$（或 1），因此该比特已完全确定；消息 0 表示目前认为两值同样可能。每个消息最多改变一次，从 0 变成某个有符号无穷。

习题 15.9. 为证明上述性质，考察某消息首次从 $+\infty$ 变成 *0* 的时刻 t_1，追问 t_1-1 时发生了什么。

因此达到不动点所需的更新数不超过边数 $N\Lambda'(1)$。若一整轮所有 $h_{i\to a}$ 都不变，以后也不会进展，这是明确的停止准则。

等价的剥离算法将解码视为线性代数问题：码满足 $Hx=0$，擦除信道固定未擦除比特，剩下关于擦除比特的线性系统 L，未必齐次。若某方程只有一个非零系数变量，就解出它并代回所有方程，递归重复，直至全部变量确定（成功），或剩余方程各含至少两个变量（卡住）。

习题 15.10. 用停止集（或 *2*-核）刻画剥离不动点。停止集 S 是变量节点子集，使每个校验在 S 中的邻居数为 *0* 或至少 *2*。

(a) 证明剥离停止时尚未确定的比特集 S 是停止集。

(b) 证明两个停止集的并仍是停止集，推出任意变量子集 U 中有唯一最大停止集，包含 U 中所有其他停止集。

(c) 若 U 是擦除比特集，证明剥离结果 S 就是该最大停止集。

习题 15.11. 证明剥离等价于 *BP*。沿用上一题的 S,U：

(a) 证明任意边 (i,a)、$i\in S$，全部时刻 $u_{a\to i}^{(t)}=h_{a\to i}^{(t)}=0$。

(b) 令 S' 为 *BP* 达到不动点后的未确定比特集，证明它是停止集。

(c) 由最大性推出 $S'=S$。

译注： 原 (a) 将变量消息写为 $h_{a\to i}$，与既有方向记号不一致；更重要的是，任意与 $i\in S$ 相连校验的 $u_{a\to i}$ 必为 0，但该变量朝某一校验的消息是否全为 0 须按停止集和外部信息核对。原题照录。

15.3.2 密度演化

全零发送时，消息只取 $0,+\infty$，用 $z_t=\mathbb{P}(h^{(t)}=0)$、$\widehat{z}_t=\mathbb{P}(u^{(t)}=0)$ 参数化。密度演化为

$$z_{t+1}=\epsilon\lambda(\widehat{z}_t),\qquad\qquad \widehat{z}_t=1-\rho(1-z_t). \tag{15.33}$$

消去 $\widehat{z}$，得 $z_{t+1}=F_\epsilon(z_t)$，$F_\epsilon(z)=\epsilon\lambda(1-\rho(1-z))$。原文将比特错误率写为 $P_b^{(t)}=\epsilon\Lambda(\widehat{z}_t)$。**译注：**这个量是尚未确定的比特比例；若按式 (15.10) 对未确定比特公平猜测，实际比特误码率应另有 $1/2$。原量照录。

(3,6) 正则系综有 $\lambda(z)=z^2,\rho(z)=z^5$，原文进而写 $F_\epsilon(z)=\epsilon[1-(1-z)^2]^5$，图 15.4 示意阈值两侧递推。**译注：**原显式表达式把指数 2 与 5 对调，与一般定义不符；按源保留，未修改曲线。

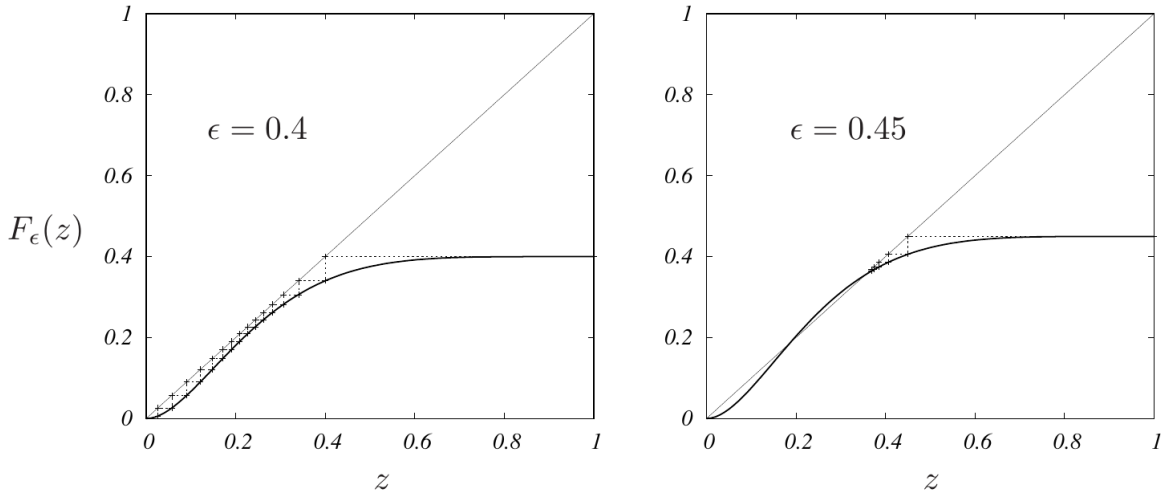


图 15.4: (3,6) LDPC 系综在 BEC(ϵ) 上的密度演化，取阈值 $\epsilon_d=0.4294$ 两侧的两个擦除率。

F_ϵ 单调递增，最小变量度至少 2 时 $F_\epsilon(0)=0$，且 $F_\epsilon(1)=\epsilon<1$。因此 z_t 单调下降，趋于最大不动点。特别地，$z_t\to 0$ 当且仅当所有 $z\in(0,1]$ 均有 $F_\epsilon(z)<z$，故阈值为

$$\epsilon_d=\inf\left\{\frac{z}{\lambda(1-\rho(1-z))}:z\in(0,1]\right\}. \tag{15.34}$$

局部稳定阈值为 $\epsilon_{\mathrm{loc}}=1/[\lambda'(0)\rho'(1)]$，它是上述比值在 $z\to 0$ 的极限，显然 $\epsilon_d\le\epsilon_{\mathrm{loc}}$。两种情形对应不同转变：一般[3]当两阈值相等，阈值上方 $P_b^{\mathrm{BP}}(\epsilon_d+\delta)=C\delta+O(\delta^2)$，连续出现；若严格小于，则有跃变 $P_b^{\mathrm{BP}}(\epsilon_d+\delta)=P_b^{\mathrm{BP},*}+C\delta^{1/2}+O(\delta)$，见图 15.5。

[3]其他行为也可能，但对度分布扰动不稳健。

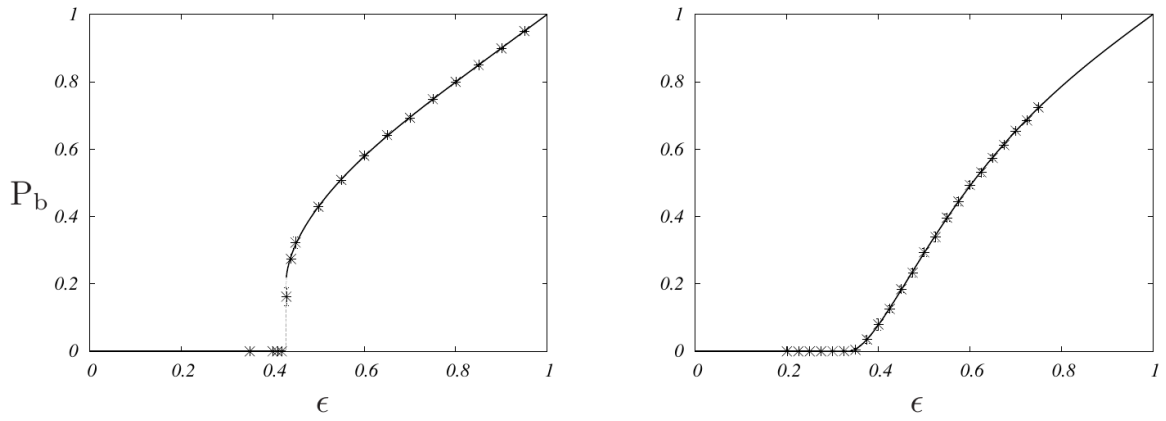


图 15.5: BP 解码下 (3,6)（左）与 (2,4)（右）系综的比特错误率。粗线是密度演化，点为码长 10^4、10 次码 / 信道实现平均的模拟。(3,6) 中 $\epsilon_{\mathrm{BP}} \simeq 0.4294 < \epsilon_{\mathrm{loc}} = \infty$，转变不连续；(2,4) 中原图注写 $\epsilon_{\mathrm{BP}} = \epsilon_{\mathrm{loc}} = 1/4$，转变连续。

译注： 原 (2,4) 图注的局部阈值 $1/4$ 与 $1/[\lambda'(0)\rho'(1)] = 1/3$ 不符，图注原值照录。

习题 15.12. *考虑固定码率 $R = 1 - l/k$、$k, l \to \infty$ 的正则 (k, l) 系综，在 BEC 上证明 BP 阈值 $\epsilon_d \to 0$。*

译注： 原题将正则度对次序写为 (k, l)，其码率公式沿用变量度 l、校验度 k 的约定；保留原题。

15.3.3 系综优化

显式阈值使 BEC 的码优化成为可能。固定噪声 $\epsilon \in (0, 1)$，给定边度分布对 λ, ρ，设计码率为 $R = 1 - (\sum_k \rho_k/k)/(\sum_l \lambda_l/l)$。原文说目标是在保持 $\epsilon_d(\lambda, \rho) \le \epsilon$ 下最大化码率。固定校验度分布后，转为无限维线性规划：

$$\begin{aligned} &\text{最大化} \sum_l \lambda_l/l, \\ &\text{满足} \sum_l \lambda_l = 1, \quad \lambda_l \ge 0 \ (\forall l), \\ &\qquad \epsilon\lambda(1 - \rho(1 - z)) \le z \quad (\forall z \in (0, 1]). \end{aligned} \tag{15.35}$$

译注： 原目标句的阈值方向 $\le$ 与可靠解码目标及所列约束不一致，照录。约束要求对应阈值不低于工作噪声。

约束左侧与目标都随各 λ_l 增加，因而相互竞争。原文称，像通常线性规划一样，最大值在所有约束饱和，即所有 z 均满足 $\epsilon\lambda(1 - \rho(1 - z)) = z$ 时取得。由此可在给定 ρ 时导出 λ。对统一校验度 k，$\rho(z) = z^{k-1}$，饱和条件给出 $\lambda(z) = \epsilon^{-1}[1 - (1 - z)^{1/(k-1)}]$，Taylor 展开得 $l \ge 2$ 时

$$\lambda_l = \frac{(-1)^l}{\epsilon} \frac{\Gamma(\frac{1}{k-1} + 1)}{\Gamma(l)\Gamma(\frac{1}{k-1} - l + 2)}. \tag{15.36}$$

特别地，$\lambda_2 = 1/[(k-1)\epsilon]$、$\lambda_3 = (k-2)/[2(k-1)^2\epsilon]$，大 l 时 $\lambda_l \simeq \lambda_\infty l^{-k/(k-1)}$。但总和 $\lambda(1) = 1/\epsilon$ 不满足归一化。通过截断级数并取 $k \to \infty$ 可克服，得到 BP 下可靠通信且码率趋

于容量 $C(\epsilon)=1-\epsilon$ 的系综序列。**译注：**将所有连续约束同时饱和不能仅由一般线性规划原理推出；这里保留原启发式推导，具体可行构造由后续定理 / 习题承担。

定理 15.12. 给定 $\epsilon\in(0,1)$，存在度分布对序列 $\{(\lambda^{(k)},\rho^{(k)})\}_k$，其中 $\rho^{(k)}(x)=x^{k-1}$，使 $\epsilon_d(\lambda^{(k)},\rho^{(k)})>\epsilon$ 且 $R(\lambda^{(k)},\rho^{(k)})\to 1-\epsilon$。

下题给出具体构造，图 15.6 展示这些系综的错误概率曲线。

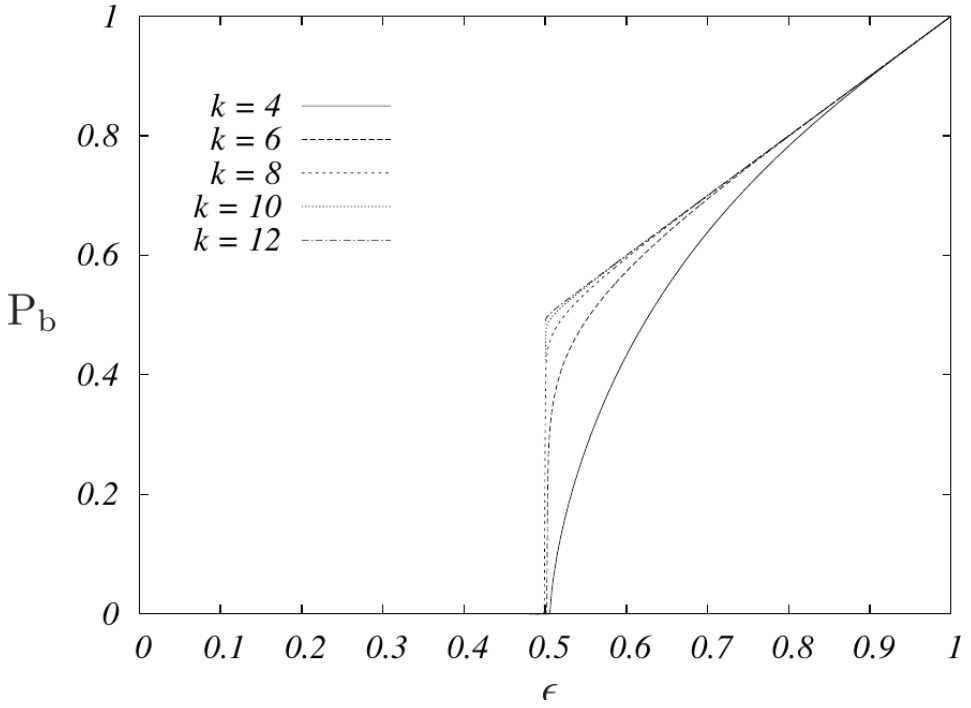


图 15.6: 达到容量序列的 BP 比特错误率。构造针对噪声 $\epsilon=0.5$，容量为 0.5；$k=4,6,8,10,12$ 的设计码率分别为 0.42253、0.48097、0.49594、0.49894、0.49976。

习题 15.13. 令 $\rho^{(k)}(z)=z^{k-1}$，$\widehat{\lambda}^{(k)}(z)=\epsilon^{-1}[1-(1-z)^{1/(k-1)}]$，$z_L=\sum_{l=2}^{L}\widehat{\lambda}_l^{(k)}$。令 $L(k,\epsilon)$ 为使 $z_L\ge 1$ 的最小 L，设 $l\le L$ 时 $\lambda_l^{(k)}=\widehat{\lambda}_l^{(k)}/z_{L(k,\epsilon)}$，否则为 0。

(a) 证明所有 $z\in(0,1]$ 均有 $\epsilon\lambda^{(k)}(1-\rho^{(k)}(1-z))<z$，从而阈值大于 ϵ。提示：利用展开系数非负，因此 $\lambda^{(k)}(x)\le\widehat{\lambda}^{(k)}(z)/z_{L(k,\epsilon)}$。

(b) 证明任意序列 $l(k)$，$\widehat{\lambda}_{l(k)}^{(k)}\to 0$，推出 $L(k,\epsilon)\to\infty$、$z_{L(k,\epsilon)}\to 1$。

(b) 证明 $\lim_{k\to\infty}R=\lim_{k\to\infty}[1-\epsilon z_{L(k,\epsilon)}]=1-\epsilon$。

译注：原题末两项重复标 (b)，提示不等式左自变量为 x、右边为 z，照录。源最后一项写的是两个极限相等；证明这两个极限相等须处理截断尾项，不能把 $1-\epsilon z_L$ 解释为每个有限 k 的精确码率。这里保留源极限等式，不将它误归因为有限 k 等式。**译注（严格阈值条件）：**逐点严格不等式 $F_\epsilon(z)<z$（每个 $z>0$）并不自动给阈值严格大于 ϵ，因为取下确界时裕量可能趋零。例如 $k=3,\epsilon=1/2$ 时，$\widehat{\lambda}_2=1, L=2, z_L=1$，所得 $\lambda(z)=z,\rho(z)=z^2$，有 $F_\epsilon(z)=z-z^2/2<z$，但 $\epsilon_d=\inf_{z\in(0,1]}1/(2-z)=1/2$。严格阈值结论须有一致裕量；例如若 $z_L>1$，该截断构造给 $\epsilon_d\ge\epsilon z_L>\epsilon$。源题与定理均保留，不把所有有限 (k,ϵ) 的此构造都当作已证严格大于。

15.4 Bethe 自由能与最优解码

大码长下，MAP 也可得到锐利渐近预测，且涉及同样的消息分布对象。考虑按物理退化排序的信道族，定义依赖码系综的 MAP 阈值 p_{MAP}，低于它可可靠通信，下面用 Bethe 自由能计算。

令系综平均条件熵密度 $h_N = N^{-1}\mathbb{E}H_N(X \mid Y)$。它直观上估计给定典型输出时具有不可忽略概率的输入数。若远离 0，典型输出对应指数多个输入；若趋于 0，正确输入在次指数多个候选中。这与错误率的精确联系由 Fano 不等式给出。

命题 15.13. *码长 N 的符号错误率为 P_b^N，则 $\mathcal{H}(P_b^N) \geq H_N(X \mid Y)/N$。特别地，熵密度远离 0 时，错误率也远离 0。*

尽管只是界，它提示将 MAP 阈值识别为熵密度趋于 0 的最大噪声：

$$p_{\mathrm{MAP}} = \sup\{p : \lim_{N\to\infty} h_N = 0\}. \tag{15.37}$$

条件熵直接联系后验图模型自由熵：

$$H_N(X \mid Y) = \mathbb{E}_y \log_2 Z(y) - N\sum_{y} Q(y \mid 0)\log_2 Q(y \mid 0). \tag{15.38}$$

证明先用链式法则

$$H(X \mid Y) = H(Y \mid X) + H(X) - H(Y). \tag{15.39}$$

均匀码字输入给出 $H(X) = NR$，无记忆及对称性给出 $H(Y \mid X) = -N\sum_y Q(y \mid 0)\log_2 Q(y \mid 0)$。再把后验写为

$$p(x \mid y) = \frac{|C|}{Z(y)} p(y, x). \tag{15.40}$$

由 Bayes 法则识别 $Z(y) = |C|p(y)$，合并即得。

自由熵是非平凡项，大码长 LDPC 中自然用 Bethe 近似。设消息 u, h 解 BP 不动点式

$$h_{i\to a} = B_i + \sum_{b\in \partial i\setminus a} u_{b\to i}, \qquad u_{a\to i} = \operatorname{atanh}\left\{ \prod_{j\in\partial a\setminus i} \tanh h_{j\to a} \right\}. \tag{15.41}$$

则自由熵为

$$\begin{aligned} \Phi(u,h) = &- \sum_{(ia)\in E} \log_2 \left[\sum_{x_i} P_{u_{a\to i}}(x_i) P_{h_{i\to a}}(x_i) \right] \\ &+ \sum_{i=1}^{N} \log_2 \left[\sum_{x_i} Q(y_i \mid x_i) \prod_{a\in\partial i} P_{u_{a\to i}}(x_i) \right] \\ &+ \sum_{a=1}^{M} \log_2 \left[\sum_{x_a} I_a(x) \prod_{i\in\partial a} P_{h_{i\to a}}(x_i) \right]. \end{aligned} \tag{15.42}$$

这里 $P_u(0)=1/(1+e^{-2u})$、$P_u(1)=e^{-2u}/(1+e^{-2u})$。关心对码与信道实现的平均。假设消息渐近同分布（原文写 $u_{a\to i}\overset{d}{=}u, h_{i\to a}\overset{d}{=}u$），同一节点不同输入渐近独立，则

$$\lim_{N\to\infty}\frac{1}{N}\mathbb{E}_y\Phi(\widehat{m},h)=\varphi-\sum_{y}Q(y\mid 0)\log_2 Q(y\mid 0), \tag{15.43}$$

其中

$$\begin{aligned}\varphi=&-\Lambda'(1)\mathbb{E}_{u,h}\log_2\left[\sum_x P_u(x)P_h(x)\right]\\&+\mathbb{E}_l\mathbb{E}_y\mathbb{E}_{\{u_l\}}\log_2\left[\sum_x\frac{Q(y\mid x)}{Q(y,0)}\prod_{i=1}^{l}P_{u_l}(x)\right]\\&+\frac{\Lambda'(1)}{P'(1)}\mathbb{E}_k\mathbb{E}_{\{h_i\}}\log_2\left[\sum_{x_1\cdots x_k}I_a(x)\prod_{i=1}^{k}P_{h_i}(x_i)\right].\end{aligned} \tag{15.44}$$

k,l 分别按 P_k,Λ_l 分布；u_i,h_i 为独立同分布副本。**译注：**原文 h 消息误写为与 u 同分布；式 (15.43) 的 $\widehat{m}$、式 (15.44) 的分母 $Q(y,0)$ 和乘积 P_{u_l} 均按源保留，分别与 u、$Q(y\mid 0)$、按 i 变化的消息有记号冲突。原排式第二行末还多出一个减号，下一行又以加号开始，存在排版歧义；此处把第三项按明确的加号排出，并记录该孤立减号。由前两式直接合并时，熵常数项符号也需核对；本稿不静默修复它来宣称条件熵公式已证。

若 Bethe 自由能正确，φ 应给出条件熵密度。此猜想的一侧可严格证明：

定理 15.14. *若 u,h 为对称变量，满足 $u\overset{d}{=}\operatorname{atanh}\{\prod_{i=1}^{k-1}\tanh h_i\}$，则*

$$\lim_{N\to\infty}h_N\geq\varphi_{u,h}. \tag{15.45}$$

自然猜想优化下界即得正确极限：

$$\lim_{N\to\infty}h_N=\sup_{u,h}\varphi_{u,h}, \tag{15.46}$$

上确界取遍满足校验分布式及 $h\overset{d}{=}B+\sum_{a=1}^{l-1}u_a$ 的对称变量对。BEC 上一大类 LDPC 系综（包括正则系综）已证明该猜想。它连接 BP 与 MAP，例如蕴含 $p_{\mathrm{BP}}\leq p_{\mathrm{MAP}}$。

习题 15.14. *(a) 任意噪声下 $u,h=+\infty$ 都是密度演化不动点。证明此时 $\varphi_{h,u}=0$。*

(b) 利用物理退化排序，证明若存在其他不动点，密度演化就收敛到它。

(c) 推出 $p_{\mathrm{BP}}\leq p_{\mathrm{MAP}}$。

译注：原 (b) 未明确初始化及多个其他不动点时的选择，按原保留，不能由此得出任意初值都到任意指定不动点。

变分公式先验上是无限维优化；实际可如下近似：

1. 初始化一对对称变量 $h^{(0)},u^{(0)}$；

2. 数值运行密度演化至近似不动点；

3. 强制校验分布式精确成立后，在该点求 $\varphi_{u,h}$。

重复不同初值，取所得最大值估计极限。此法不保证穷尽全部不动点，但给出一系列熵密度下界。类比 BEC 等可解例子，人们预计仅有少量不动点；特别是正则系综在 $p > p_{\mathrm{BP}}$ 时，除无误差点外预计仅有一个稳定不动点。相应阈值见表 15.2。

表 15.2: BSC 上几个正则系综的 MAP 阈值与 BP 阈值比较。

l	k	R_{des}	p_d	p_{MAP}	Shannon 极限
3	4	1/4	0.1669(2)	0.2101(1)	0.2145018
3	5	2/5	0.1138(2)	0.1384(1)	0.1461024
3	6	1/2	0.0840(2)	0.1010(2)	0.1100279
4	6	1/3	0.1169(2)	0.1726(1)	0.1739524

注释

Robert Gallager 在博士论文（Gallager, 1963）中首次将 BP 用于解码, 称和积算法; 同篇还提出若干低复杂度消息传递及分析基本思想。Luby 及同事开创非正则系综擦除信道迭代解码分析, 并给出首批达到容量的序列（Luby、Mitzenmacher、Shokrollahi、Spielman 和 Stemann, 1997；Luby、Mitzenmacher、Shokrollahi 和 Spielman，1998；2001a；2001b）。

Richardson 和 Urbanke（2001b） 引入一般 BMS 信道的密度演化。综述 Richardson 和 Urbanke（2001a） 及当时即将出版的专著（2006）介绍整个领域。本章略去的重要性质是集中性：大多数码的消息传递错误概率接近密度演化预测的系综平均。

一般 BMS 下接近容量的 LDPC 设计见 Chung、G. David Forney、Richardson 和 Urbanke（2001），以及 Richardson、Shokrollahi 和 Urbanke（2001）。既然解码高效，先验复杂度为 $O(N^2)$ 的编码是否会成为瓶颈？高效编码方案见 Richardson 和 Urbanke（2001c）。

MAP 阈值的紧界最先由 Montanari（2005） 证明，Macris（2005）推广。另一证明采用面积定理与 Maxwell 构造（Méasson、Montanari、Richardson 和 Urbanke，2005b）；擦除信道上界的紧性由 Méasson、Montanari 和 Urbanke（2005a） 证明。

本章分析适用于大码长极限。实际中大码长意味着通信延迟，因而许多工作研究适中码长的估计与优化。可从以下文献进入这一领域：Di、Proietti、Richardson、Telatar 和 Urbanke（2002）；Amraoui、Montanari、Richardson 和 Urbanke（2004）；Amraoui、Montanari 和 Urbanke（2007）；Wang、Kulkarni 和 Poor（2006）；Kötter 和 Vontobel（2003）；Stepanov、Chernyak、Chertkov 和 Vasic（2005）。

第十六章　分配问题

有 N 名“执行者”和 N 项“工作”，给定代价矩阵 E_{ij}，表示执行者 i 完成工作 j 的代价。寻找总代价最小的分配，是最经典的组合优化问题之一。最小代价（也称最大权）分配有广泛应用，并能在多项式时间求解，因此促进了算法与概率方面的大量理论发展。

这里将它作为消息传递的应用。尽管一般实例的因子图并非局部树状，仍可证明最小和在多项式时间内收敛到最优解，是该方法的成功案例。BP 也可计算分配的加权和，但保证弱得多。随机独立同分布代价的典型性质，可用 RS 腔方法启发式计算，而且这些结果能完全严格化。

不过，看似无害的改动也可能破坏 RS 图景。例如多指标分配（同时匹配执行者、工作和住房），即使随机实例也需要后续章节的复本对称性破缺思想。第 16.1 节定义问题；第 16.2 节用腔方法求随机最优代价；第 16.3 节证明最小和收敛；第 16.4 节的组合证明验证腔结果并给出更精细估计；第 16.5 节讨论多重分配。

16.1　分配及随机分配系综

实例由 $i \in A$（执行者）、$j \in B$（工作）的矩阵决定，$|A| = |B| = N$，常将两集合均与 $\{1,\dots,N\}$ 等同，并交替使用代价与能量。分配是两者间的一一映射，即排列 π，总代价 $E(\pi) = \sum_i E_{i\pi(i)}$；求其最小值。

也可在顶点集 A, B 的完全二分图上描述，每条边带权 E_{ij}，任务是找最小权完美匹配：边子集 M 使每个顶点恰与一条所选边相接，见图 16.1。下面关心：给定实例能否由消息传递高效求解，以及随机独立代价 $E_{ij} \sim \rho(E)$ 时的典型性质。特别方便的是指数密度 $\rho(E) = e^{-E}\mathbb{I}(E \geq 0)$。腔方法可处理更一般密度，但指数代价极大简化组合方法。

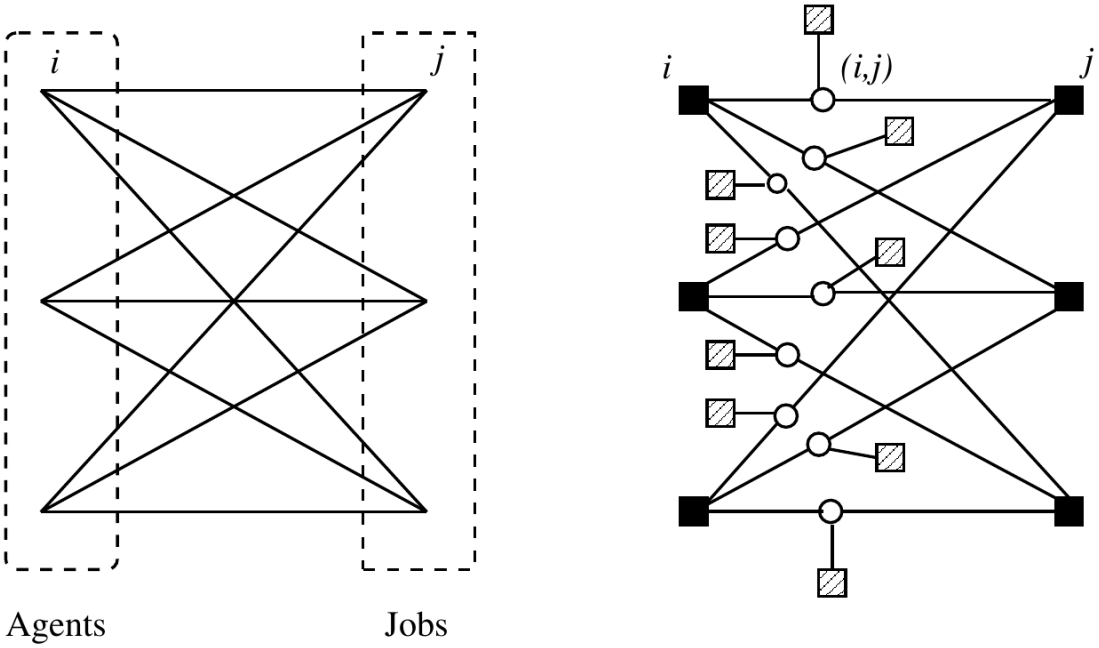


图 16.1: 左：3 名执行者、3 项工作的分配图，每条边带代价（未显示），寻找最小代价完美匹配。右：相应因子图；虚线方框表示边权对应的函数节点。

16.2 消息传递及其概率分析

16.2.1 统计物理表述与计数

引入有限逆温度 β，对匹配赋予权重。边 (i,j) 的占据数 $n_{ij}\in\{0,1\}$ 表示是否选择该边。要求所选边构成匹配，即

$$\sum_{j\in B} n_{ij}\le 1 \quad (\forall i\in A), \qquad\qquad \sum_{i\in A} n_{ij}\le 1 \quad (\forall j\in B). \tag{16.1}$$

对占据矩阵 n 定义

$$p(n)=\frac{1}{Z}\prod_{i\in A}\mathbb{I}\left(\sum_{j\in B} n_{ij}\le 1\right)\prod_{j\in B}\mathbb{I}\left(\sum_{i\in A} n_{ij}\le 1\right) \times\prod_{(ij)} e^{-\beta n_{ij}(E_{ij}-2\gamma)}. \tag{16.2}$$

硬约束使支撑集为匹配。$\exp(2\beta\gamma\sum n_{ij})$ 是软约束，$\gamma\to\infty$ 时分布集中于完美匹配，因子 2 为后文方便而引入；随后 $\beta\to\infty$，集中于最小代价分配。

软化哪项约束及如何软化有很大任意性；这里使模型接近本书一般图模型。因子图有 N^2 个边变量，N^2 个对应权重的度 1 函数节点，以及 $2N$ 个对应 A,B 顶点的度 N 函数节点。变量 (ij) 连到 i,j 两个约束节点，及自身边权节点。

随机实例的热力学极限须使能量、熵可竞争。均值 1 指数代价下，最优总代价以高概率为 $O(1)$：直观上，对任一执行者，固定第 k 小代价为 $O(1/N)$，下一题给出更正式的论证轮廓。相

关熵为 $O(N)$[1]，故重标度代价。后面腔分析始终取 $\widehat{\rho}(E) = N^{-1}e^{-E/N}$，使最优匹配中占据边有有限代价。

习题 16.1. 代价为均值 η 的独立指数变量。令贪心映射 $\pi_1(i)$ 选择该执行者最便宜的工作，$E_1 = \sum_i E_{i\pi_1(i)}$。

(a) 证明 $\mathbb{E}E_1 = \eta$。

(b) 贪心映射未必单射。令碰撞数 C 为被至少两人选择的工作数，证明 $\mathbb{E}C = N(1-2/e) + O(1)$，且 C 紧集中于均值附近。

(c) 若某工作仅被一人选择，保留该配对；对每个碰撞工作及选择它的每名执行者，在尚未匹配的工作中选择代价最低者，得到 π_2。求 E_2 的期望及剩余碰撞数。

(d) 如何继续这一构造？

16.2.2 信念传播方程

用 $i \in A, j \in B$ 标记顶点，右向左的消息为

$$\nu_{ij\to i}(n_{ij}) \cong \widehat{\nu}_{j\to ij}(n_{ij}) e^{-\beta n_{ij}(E_{ij}-2\gamma)}, \tag{16.3}$$

$$\widehat{\nu}_{j\to ij}(n_{ij}) \cong \sum_{\{n_{kj}\}} \mathbb{I}\left(n_{ij} + \sum_{k\in A\setminus i} n_{kj} \le 1\right) \prod_{k\in A\setminus i} \nu_{kj\to j}(n_{kj}). \tag{16.4}$$

反向消息由交换两集合角色得到。二元消息用重标度对数似然参数化：

$$x^L_{j\to i} = \gamma + \frac{1}{\beta}\log\frac{\widehat{\nu}_{j\to ij}(1)}{\widehat{\nu}_{j\to ij}(0)}, \qquad x^R_{i\to j} = \gamma + \frac{1}{\beta}\log\frac{\widehat{\nu}_{i\to ij}(1)}{\widehat{\nu}_{i\to ij}(0)}. \tag{16.5}$$

变量到函数的消息可由它们轻易恢复，BP 式成为

$$\begin{aligned} x^L_{j\to i} &= -\frac{1}{\beta}\log\left[e^{-\beta\gamma} + \sum_{k\in A\setminus i} e^{-\beta E_{kj} + \beta x^R_{k\to j}}\right], \\ x^R_{i\to j} &= -\frac{1}{\beta}\log\left[e^{-\beta\gamma} + \sum_{k\in B\setminus j} e^{-\beta E_{ik} + \beta x^L_{k\to i}}\right]. \end{aligned} \tag{16.6}$$

因子图帮助写出方程，但简化后不再显含它，可以直接视为原完全二分图上的消息传递。

习题 16.2 (边缘分布)**.** 证明 $\langle n_{ij}\rangle$ 的 *BP* 估计为 $t_{ij}/(1+t_{ij})$，其中 $t_{ij} = \exp[\beta(x^L_{j\to i} + x^R_{i\to j} - E_{ij})]$。

[1]分配总数 $N!$ 对应 $O(N\log N)$ 熵；但只允许与最优代价相当的工作选择时，熵为 $O(N)$。

由一般 Bethe 公式，经过直接但冗长的计算得自由熵估计

$$F(x) = 2N\beta\gamma - \sum_{i\in A, j\in B} \log[1 + e^{-\beta(E_{ij} - x^R_{i\to j} - x^L_{j\to i})}] + \sum_{i\in A} \log\left[e^{-\beta\gamma} + \sum_j e^{-\beta(E_{ij} - x^L_{j\to i})}\right] + \sum_{j\in B} \log\left[e^{-\beta\gamma} + \sum_i e^{-\beta(E_{ij} - x^R_{i\to j})}\right]. \tag{16.7}$$

习题 16.3. 计算模型的 *Bethe* 自由熵：

(a) 证明有三类函数节点项、一类变量项、三类混合边项。

(b) 证明边权对应函数项与涉及同一函数节点和变量 (ij) 的混合项完全抵消。

(c) 显式写出其余项，以 x^R, x^L 表示并导出式 (16.7)。提示：每条消息独立重标度不改变一般 *Bethe* 表达式。

16.2.3 零温：最小和算法

先取 $\gamma \to \infty$ 再取 $\beta \to \infty$，假定消息有限，则

$$x^L_{j\to i} = \min_{k\in A\setminus i}(E_{kj} - x^R_{k\to j}), \qquad x^R_{i\to j} = \min_{k\in B\setminus j}(E_{ik} - x^L_{k\to i}). \tag{16.8}$$

也可直接由最小和规则推导。

习题 16.4. 对模型应用最小和：

(a) 证明度 *1* 边权因子向变量 (ij) 的消息是 $n_{ij}(E_{ij} - 2\gamma)$。

(b) 写出其他更新式，消去变量到函数消息，证明

$$\widehat{J}_{i\to ij}(1) = \sum_{k\in B\setminus j} \widehat{J}_{k\to ik}(0),$$
$$\widehat{J}_{i\to ij}(0) = \sum_{k\in B\setminus j} \widehat{J}_{k\to ik}(0) + \min\{0, T_{ij}\},$$
$$T_{ij} = \min_{l\in B\setminus j}\{\widehat{J}_{l\to il}(1) - \widehat{J}_{l\to il}(0) + E_{il} - 2\gamma\}.$$

(c) 定义 $x^R_{i\to j} = \widehat{J}_{i\to ij}(0) - \widehat{J}_{i\to ij}(1) + \gamma$，类似地原文写 $x^L_{i\to j} = \widehat{J}_{j\to ij}(0) - \widehat{J}_{j\to ij}(1) + \gamma$，以此改写方程。

(d) 证明大 γ 极限得到式 (16.8)。

译注： 原 (c) 左向消息下标写为 $i \to j$，与前文 $j \to i$ 相反，照录。

基态代价可由 $-F/\beta$ 的双极限取得，或利用最大边缘估计。定义

$$J_{ij}(n_{ij}) = n_{ij}(E_{ij} - 2\gamma) + \widehat{J}_{i\to ij}(n_{ij}) + \widehat{J}_{j\to ij}(n_{ij}), \tag{16.9}$$
$$n^*_{ij} = \arg\min_{n\in\{0,1\}} J_{ij}(n). \tag{16.10}$$

$e^{-J_{ij}(n)}$ 是相应最大边缘的消息传递估计。忽略多个最优分配的情形（本章随机系综中其概率为 0），若估计准确，则最优分配中 $n_{ij}=n_{ij}^{*}$，基态能量为 $\sum_{ij} n_{ij}^{*}E_{ij}$。$\gamma\to\infty$ 时得到纳入准则：边 (ij) 属于最优分配，当且仅当 $E_{ij}\le x_{i\to j}^{R}+x_{j\to i}^{L}$。可与边缘分布习题比较。**译注：**由自由能极限提取原代价时还须加回软约束的基准 $2N\gamma$；原文此句未显式写出，照录。等号及简并情形需结合排除多最优解的约定。

16.2.4 分布不动点与 $\zeta(2)$

取均值 N 的独立指数边代价，用密度演化分析最小和。完全二分图不局部树状，似乎不满足一般框架。不过可先删去 $E_{ij}>E_{\max}$ 的变量及边。典型边代价为 $\Theta(N)$，固定截止下剩图稀疏，密度演化适用。 ⋆

另一方面，可证明截止造成的误差有关于 N 一致的界，并随 $E_{\max}\to\infty$ 消失。下面走捷径，先为有限 N 直接写分布式，再形式取极限。令 $A_{N,t}(x)=\mathbb{P}(x_{i\to j}^{(t)}\ge x)$；偶数 t 为右向、奇数为左向消息，则 $A_{N,t+1}(x)=[1-\mathbb{E}A_{N,t}(E-x)]^{N-1}$。腔方法寻找不动点

$$A_N(x)=\left[1-\mathbb{E}A_N(E-x)\right]^{N-1}. \tag{16.11}$$

若它有弱极限 A，则

$$\begin{aligned}\mathbb{E}A_N(E-x)&=\frac{1}{N}\int_{-x}^{\infty}A_N(y)e^{-(x+y)/N}\,dy\\&=\frac{1}{N}\int_{-x}^{\infty}A(y)\,dy+o(1/N),\end{aligned} \tag{16.12}$$

$$A(x)=\exp\left\{-\int_{-x}^{\infty}A(y)\,dy\right\}. \tag{16.13}$$

方程有唯一解 $A(x)=1/(1+e^{x})$，原文称对应密度 $a(x)=A'(x)=1/[4\cosh^{2}x]$，并可证明密度演化收敛到它。**译注：**这里 A 是递减的尾分布，密度应为 $-A'$，且实际为 $1/[4\cosh^{2}(x/2)]$；原文本段符号及自变量不一致。原表述保留，后图注确实采用 $x/2$ 形式。弱收敛本身也不足以直接推出上述无界积分的渐近式，须有尾部控制。

RS 假设下，由纳入准则，给定边代价 E 后其入选概率为

$$\begin{aligned}q(E)&=\int\mathbb{I}(x_1+x_2\ge E)a(x_1)a(x_2)\,dx_1dx_2\\&=\frac{1+(E-1)e^{E}}{(e^{E}-1)^{2}}.\end{aligned} \tag{16.14}$$

最优总代价期望为边数乘上边代价与入选指标的平均，故

$$\begin{aligned}E_{*}&=N^{2}\int_{0}^{\infty}EN^{-1}e^{-E/N}q(E)\,dE+o(N)\\&=N\int_{0}^{\infty}E\frac{1+(E-1)e^{E}}{(e^{E}-1)^{2}}\,dE+o(N)=N\zeta(2)+o(N),\end{aligned}$$

其中

$$\zeta(2)=\sum_{n=1}^{\infty}\frac{1}{n^{2}}=\frac{\pi^{2}}{6}\simeq 1.64493406684823. \tag{16.15}$$

还原均值 1 代价，得 $E_* = \zeta(2) + o(1)$。读者可检验，推导只依赖边代价在 0 附近的行为；更确切地，任意 $\rho(0) = 1$ 的密度下，最优代价都趋于 $\zeta(2)$。**译注（零点附近的密度）：**此处应按 $E \downarrow 0$ 时 $\rho(E) \to 1$ 一类局部正则条件理解；仅指定密度在单点 0 的取值不足以约束分布。例如 $[1,2]$ 上的均匀分布即使另定义 $\rho(0) = 1$，分布仍不改变，而任意完美匹配的代价至少为 N，不可能趋于 $\zeta(2)$。这里不据此补充一般重尾情形的充分定理。

习题 16.5. 若代价支持在 $\mathbb{R}_+$，且 $E \downarrow 0$ 时 $\rho(E) \simeq E^r$，$r > 0$：

(a) 证明为使最优权重为 $O(N)$，应重标度为 $E_{ij} = N^{r/(r+1)} \widetilde{E}_{ij}$（原式指数印作 $r/r+1$），$\widetilde{E}$ 服从 ρ。

(b) 证明 *RS* 腔方法下极限消息满足

$$A(x) = \exp\left\{ - \int_{-x}^{\infty} (x+y)^r A(y)\, dy \right\}. \tag{16.16}$$

(c) 假定解唯一且 *RS* 成立，证明重标度问题 $E_* = N\epsilon_r + o(N)$，其中

$$\epsilon_r = \int A(x) \log[1/A(x)]\, dx.$$

从而原问题代价为 $N^{r/(r+1)} e_r (1 + o(1))$。

(d) 用种群动力学数值解方程，编写相应程序，证明 $r = 1, 2$ 的最优匹配代价常数分别约为 $e_1 = 0.8086, e_2 = 0.6382$。

译注：原 (a) 重标度指数与 (c) 还原标度不相容：若原最优代价为 $N^{r/(r+1)}$，要使它变为 $O(N)$ 应乘 $N^{1/(r+1)}$。原 e_r, ϵ_r 两种记号也未在此解释关系；按源保留。题 (d) 是原练习要求，本翻译没有执行数值模拟来认证所给常数。

16.2.5 非零温度与稳定性分析

前面的启发式讨论能否严格论证？完整严格化超出本章范围，但可继续在启发式层面检查一致性：BP 是否近似真实边缘，以及密度演化是否可分析随机实例。直观上要有局部树状图，及变量关联随距离足够快衰减。

完全二分图似乎远非局部树状，但只有 $O(1)$ 代价边重要。仍取均值 N 的重标度代价，删去 $E_{ij} > 2\gamma$ 的边。大 β 时它们本就不被占据，因此该修改无关紧要。$N \to \infty$ 时，剩余顶点度趋于均值 2γ 的 Poisson 分布，存活边代价趋于 $[0, 2\gamma]$ 上独立均匀变量。固定 β, γ 的 RS 消息式为

$$x \stackrel{d}{=} -\frac{1}{\beta} \log \left[e^{-\beta\gamma} + \sum_{r=1}^{k} e^{-\beta(E_r - x_r)} \right], \tag{16.17}$$

$k \sim \mathrm{Poisson}(2\gamma)$，$E_r$ 独立均匀，x_r 为 x 的独立副本。可用种群动力学估计；大 β, γ 时迅速趋于 $a(x) = 1/[4\cosh^2(x/2)]$，见图 16.2。

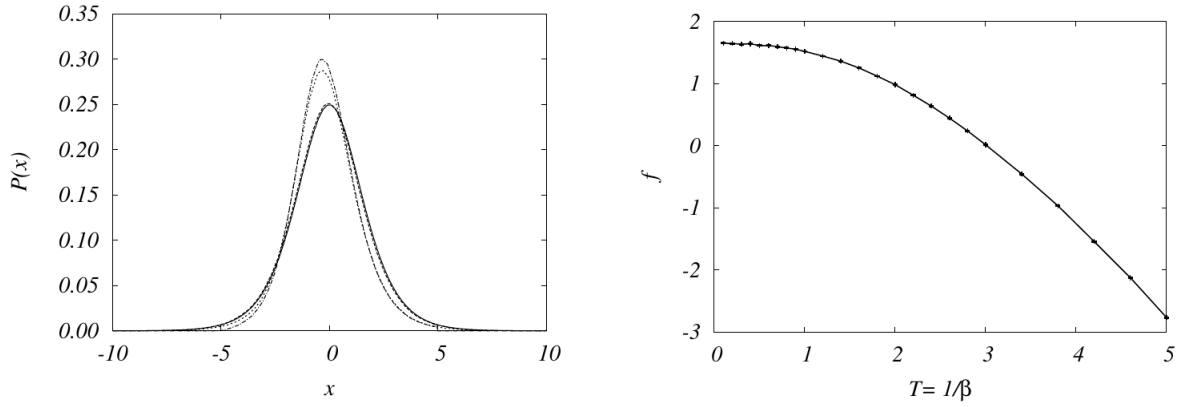


图 16.2: 左：删去昂贵边后，种群动力学估计消息密度。从上到下为 $(\beta,\gamma) = (1,5),(1,60),(10,60)$；末条与 $\beta = \gamma = \infty$ 的解析密度几乎重合，更大 γ 也无法在此尺度区分。种群大小 10^5，整体更新 100 次。右：自由能对温度 $T = 1/\beta$，消息分布取 $\gamma = 40$。

假设输入消息独立，$\mathbb{E}F(x) = -N\beta f(\beta,\gamma) + o(N)$，其中

$$f(\beta,\gamma) = -2\gamma - \frac{2}{\beta}\mathbb{E}\log\left[e^{-\beta\gamma} + \sum_{j=1}^{k} e^{-\beta(E_j - x_j)}\right] + \frac{2\gamma}{\beta}\mathbb{E}\log[1 + e^{-\beta(E_1 - x_1 - x_2)}]. \tag{16.18}$$

局部树状只是必要条件，还要求不同占据变量关联随因子图距离快速衰减。用自旋玻璃磁化率衡量：

$$\chi_{\mathrm{SG}} = \frac{1}{N}\sum_{e,f}(\langle n_e n_f\rangle - \langle n_e\rangle\langle n_f\rangle)^2. \tag{16.19}$$

和遍历变量节点对，即原二分图边对。若关联足够快衰减，它在大 N 极限应有界。由涨落耗散关系，连通关联正比于微扰边 e 代价时 $\langle n_f\rangle$ 的变化；这一变化符号随 f 改变。假设总变化满足中心极限定理，其典型大小由平方和的平方根给出。再对扰动边平均，便由 χ_{SG} 测量关联衰减。

用同一 RS 假设估计磁化率；若发散，假设被证伪；若有限，虽不能得出确定结论，但称假设一致、RS 解局部稳定，即对小扰动稳定。先固定距离 r，取大 N 极限计算

$$\chi_{\mathrm{SG}}^{(r)} = \frac{1}{N}\sum_{e,f:d(e,f)=r}(\langle n_e n_f\rangle - \langle n_e\rangle\langle n_f\rangle)^2, \tag{16.20}$$

再对 r 求和。固定 r 时，以高概率只有一条短路径，其余路径长 $\Theta(\log N)$。令路径变量为 $j_1,\ldots,j_r$，中间函数为 $a_2,\ldots,a_r$，$e = j_1, f = j_r$，见图 16.3。x_n 是从 a_n 到 j_n 的消息，路径

外输入为 $y_{n,p}$。BP 给出

$$x_2 = -\frac{1}{\beta}\log\left[e^{-\beta\gamma} + e^{-\beta(E_1 - x_1)} + \sum_{p=1}^{k_2} e^{-\beta(E_{2,p} - y_{2,p})}\right],$$
$$\vdots$$
$$x_r = -\frac{1}{\beta}\log\left[e^{-\beta\gamma} + e^{-\beta(E_r - x_r)} + \sum_{p=1}^{k_r} e^{-\beta(E_{r,p} - y_{r,p})}\right]. \tag{16.21}$$

译注： 末行原式右端仍是 x_r，并非递推应使用的前一消息；照录。后续链式求导需要按其所述路径递推核对。

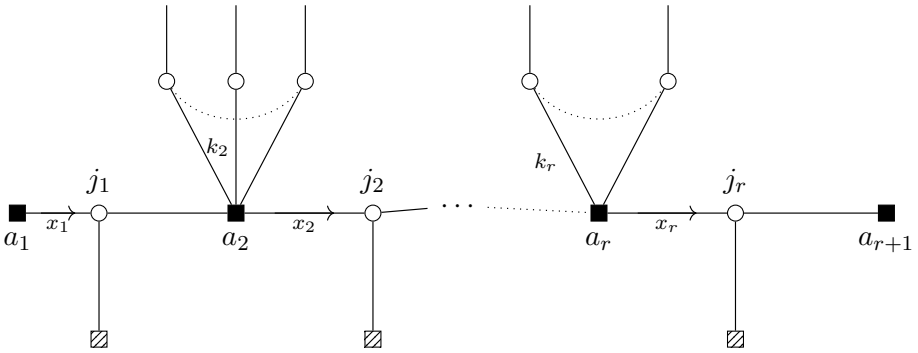


图 16.3: 用于计算 x_r 与 x_1 关联的因子图片段。

随机实例中，k_n 为均值 2γ 的独立 Poisson 变量，代价为独立均匀变量，$y_{n,p}$ 独立服从不动点分布。以 $\mathbb{E}_{\text{out}}$ 表示对路径外这些变量取平均。固定它们时，$\delta x_r = (\partial x_r/\partial x_1)\delta x_1$，由链式法则为沿途导数之积。以下关联式留作练习： ⋆

$$\langle n_e n_f\rangle - \langle n_e\rangle\langle n_f\rangle = C\frac{\partial x_r}{\partial x_1} = C\prod_{n=2}^{r}\frac{\partial x_n}{\partial x_{n-1}}, \tag{16.22}$$

其中 C 不依赖 r。距 e 为 r 的节点数期望按 $(2\gamma)^r$ 增长，故 $\mathbb{E}\chi_{\text{SG}}^{(r)} = C' e^{\lambda_r r}$，其中

$$\lambda_r(\beta,\gamma) = \log(2\gamma) + \frac{1}{r}\log\mathbb{E}_{\text{out}}\left\{\prod_{n=2}^{r}\left(\frac{\partial x_n}{\partial x_{n-1}}\right)^2\right\}. \tag{16.23}$$

因此大 r 时 λ_r 为负且一致远离 0，是期望磁化率有限的充分条件。

可用种群动力学抽取路径外消息及代价，再以大种群数值平均估计指数。被平均量随 r 指数变化，因此大 r 更难算。图 16.4 中 λ_r 对 r 依赖弱，原文预期可据此安全估计极限。数据与以下图景相容：任意有限温度 $\lambda_\infty < 0$，$\beta\to\infty$ 时按 $1/\beta$ 消失；表明磁化率有限，RS 假设一致。

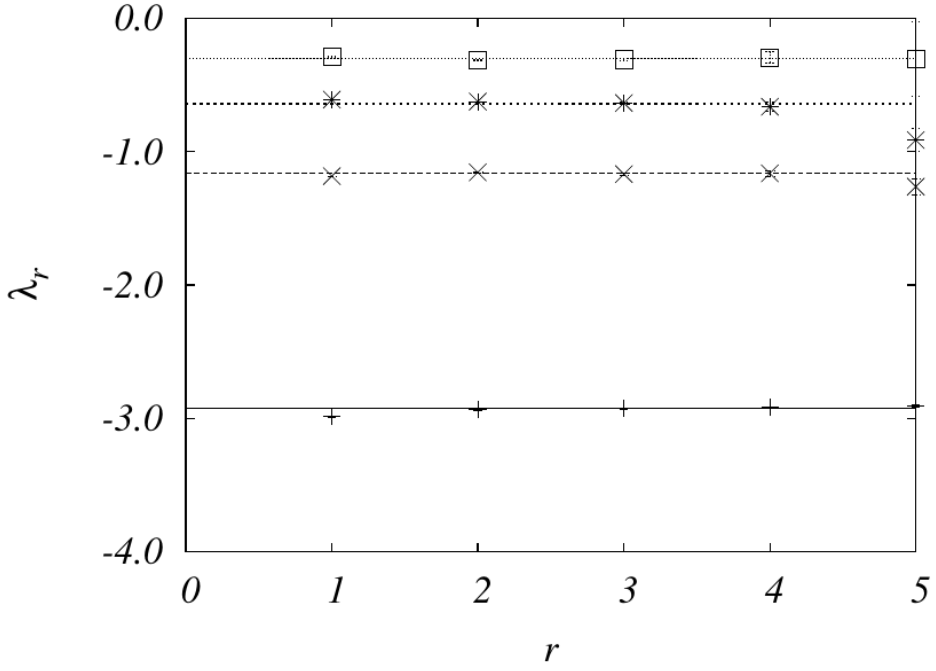


图 16.4: 式 (16.23) 的稳定性参数，逆温度 $\beta = 10, 5, 2, 1$ 从下到上。连线仅引导视线；大 r 的负极限表明有限自旋玻璃磁化率。种群大小 10^6，$\gamma = 20$。

16.3 多项式消息传递算法

最小和在最优分配唯一时可证明返回它。显式写迭代数：

$$x^L_{j\to i}(t+1) = \min_{k\in A\setminus i}[E_{kj} - x^R_{k\to j}(t)], \qquad x^R_{i\to j}(t) = \min_{k\in B\setminus j}[E_{ik} - x^L_{k\to i}(t)]. \tag{16.24}$$

译注（时间下标）： 原式第一式更新到 $t+1$，第二式却将由 $x^L(t)$ 得到的量记为 $x^R(t)$；下述伪代码又将两类消息均初始化为 0 并要求计算下一时刻。字面在 $t=0$ 使用第二式可能与初值冲突，例如 $N=2$ 且所有 $E_{ij}=1$ 时其右端为 1。这里保留原下标与伪代码；实际实现以及后续计算树论证需明确采用同步或交替调度，并说明初始步骤的例外。这一记号问题本身不说明算法不能收敛。算法为：

最小和分配（代价矩阵 E，迭代数 t_*）

1. 对所有 i, j 设 $x^L_{j\to i}(0) = x^R_{i\to j}(0) = 0$；
2. 对 $t = 0, 1, \ldots, t_*$，用式 (16.24) 计算下一时刻消息；
3. 每个 i 取 $\pi(i) = \arg\min_{j\in B}[E_{ij} - x^L_{j\to i}(t_*)]$；
4. 输出排列 π。

定理 16.1. 令 $W = \max_{ij}|E_{ij}|$，$\epsilon = \min_{\pi\neq\pi^*}[E(\pi) - E^*]$ 为最优分配 π^* 与次优代价差。任意 $t_* \geq 2NW/\epsilon$，上述最小和返回 π^*。

证明基于计算树，见后两小节。若事先不知道间隙，需停止准则。收敛后消息是“周期加漂移”：存在周期 τ 和 $C>0$，对 $t>2NW/\epsilon$，当 $j=\arg\min_{k\in B}(E_{ik}+x^L_{k\to i}(t))$ 时，$x^R_{i\to j}(t+\tau)=x^R_{i\to j}(t)+C$，其他边则减 C。将这一符号依赖的漂移简记 $x^R(t+\tau)=x^R(t)+C$。

原文进一步说明：若某 t_0,τ,C 满足此关系，则对全部 $t\ge t_0$ 均成立，而且输出排列不再依赖 $t_*\ge t_0$。证明作为研究级练习留给读者。 $\star$

由此得停止法：每次检查是否存在 $t_0<t, C>0$，使当前消息与过去消息满足上述漂移关系；若是则停止并返回排列。**译注：**漂移判别中的 $E+x^L$ 按原文保留，与算法判决中的 $E-x^L$ 不一致；这里的向量“加 C”是上述逐边正负漂移的简写。定理的迭代界依赖 W/ϵ，该界本身也未给出按一般二进制输入位长计的多项式时间保证。例如 $N=2$、$E=\left(\begin{smallmatrix}1 & 1\\ 1+\delta & 1\end{smallmatrix}\right)$，$\delta=2^{-B}$，唯一最优对角匹配代价为 2，间隙为 δ，$W=1+\delta$；界 $2NW/\epsilon=4(1+\delta)/\delta$ 随 B 指数增长。这只是该上界不能给出位长多项式保证的例子，不是实际迭代次数必然指数增长的下界，也不涉及其他拍卖算法或改进算法。原章标题及源文历史归属保持不变。

16.3.1 计算树

原完全加权二分图记为 G_N。对根 $i_0\in A$，深度 t 计算树 $T_t^{i_0}$ 为度 N 的加权根树。先设对应根 $\widehat{i_0}$，对全部 $j\in B$ 添加子节点 $\widehat{j}$，边权为 $E_{i_0 j}$。之后若 $\widehat{i}$ 对应 $i\in A$、其父节点 $\widehat{j}$ 对应 $j\in B$，就添加对应 $B\setminus j$ 的 $N-1$ 个子节点 $\widehat{k}$；原文把边权写为 $E_{\widehat{kj}}=E_{kj}$。另一侧对称。更简洁地说，这是从 i_0 出发的不回退游走树[2]。**译注：**原递归描述在添加 $\widehat{i}$ 的子节点时，边权指标却写 $\widehat{kj}$，与实际新边不一致，照录。

在树上以 0 初值运行最小和，因为局部结构相同，$s\le t$ 时根输入与原图相同：$x_{\widehat{j}\to\widehat{i_0}}(s)=x_{j\to i_0}(s)$。最小和在树上精确得到基态。定义内部匹配为边子集，使每个非叶节点恰有一条相邻边属于它，便有：

引理 16.2. *令 $\pi^t(i)=\arg\min_j[E_{ij}-x^L_{j\to i}(t)]$。计算树 T_t^i 根为 $\widehat{i}$，其对应 $\pi^t(i)$ 的子节点为 $\widehat{j}$。若最低代价内部匹配唯一，则边 $(\widehat{i},\widehat{j})$ 属于该匹配。*

习题 16.6. *令 r 为计算树中非根、非叶节点，子节点集 S_r 大小为 $N-1$，T_r 为其后代树。定义腔内部匹配，使除根 r 及叶外所有节点被匹配（原文此定义句语法不完整，按后续用途表述）。A_r 为 r 未匹配时最优代价，B_r 为匹配时代价，证明*

$$A_r=\sum_{q\in S_r}B_q,\qquad\qquad B_r=\min_{q\in S_r}\left[A_q+E_{rq}+\sum_{q'\in S_r\setminus q}B_{q'}\right]. \tag{16.25}$$

证明 $x_r=B_r-A_r$ 满足与式 (16.24) 相同的方程，从而证明引理 16.2。

译注：由所列递推直接相减，$B_r-A_r=\min_q[E_{rq}-(B_q-A_q)]$，与最小和形式一致；叶边界及计算树时间索引仍须服从源算法约定。

16.3.2 最小和收敛的证明

将分配表示为匹配，原图最优匹配为 $M_*=\{(i,\pi^*(i)):i\in A\}$。算法输出 π 未必单射，故 $M=\{(i,\pi(i))\}$ 未必是匹配。

[2]不回退游走为顶点序列 $(i_0,\dots,i_n)$，相邻顶点有边，且每个中间位置满足 $i_{s-1}\neq i_{s+1}$。

反证设 $\pi \neq \pi^*$，存在 i_0 使其输出不同。考虑深度 t 计算树，根为 $\widehat{i}_0$，最低代价内部匹配为 $\widehat{M}$，将 M_* 提升到树得 $\widehat{M}_*$。令 $j=\pi(i_0)$，对应根邻点 $\widehat{j}$。由引理，$(\widehat{i}_0,\widehat{j})\in\widehat{M}$，但不在 $\widehat{M}_*$ 中。目标是构造代价更低且不含该边的内部匹配 $\widehat{M}'$。

在对称差 $\widehat{M}\triangle\widehat{M}_*$ 中，取包含该边的连通分量 $\widehat{P}$。它是两端位于叶的路径，$2t$ 条边在两匹配间交替，见图 16.5。翻转路径，即 $\widehat{M}'=\widehat{M}\triangle\widehat{P}$，删除路径上的 $\widehat{M}$ 边、加入 $\widehat{M}_*$ 边，仍为内部匹配。下面证明大 t 时它代价更低。

将路径投影回原图，得长度 $2t$ 的不回退路径 P。可分解为 m 个简单圈[3]（可重复）及至多一条偶长路径 Q。原文说这些长度“加起来为 $2N$”，并指出 Q 长至多 $2N-2$、每个圈长至多 $2N$，因而 $m>t/N$。**译注：**总投影长度前文为 $2t$，此处原写 $2N$ 与之不符；由这些长度界直接得到的是 $m>t/N-1$，并非一般的 $m>t/N$。保留两处原表述，不据此隐去证明缺口。

每个圈 C_s 的边交替属于 M_* 与其补集。用圈上补集边替换最优边会得到另一完美匹配，故两类边的代价差至少 ϵ。对 Q 也可令第一边属于 M_*、最后边不属于它，改变最后一步使之闭成交替圈；改变代价至多 $2W$。所以 $Q\setminus M_*$ 的代价至少比 $Q\cap M_*$ 大 $\epsilon-2|W|$。汇总得到

$$E_T(\widehat{M})\geq E_T(\widehat{M}')+(m+1)\epsilon-2W.$$

$t>2NW/\epsilon$ 时，原文由此推出严格降低，矛盾。 □

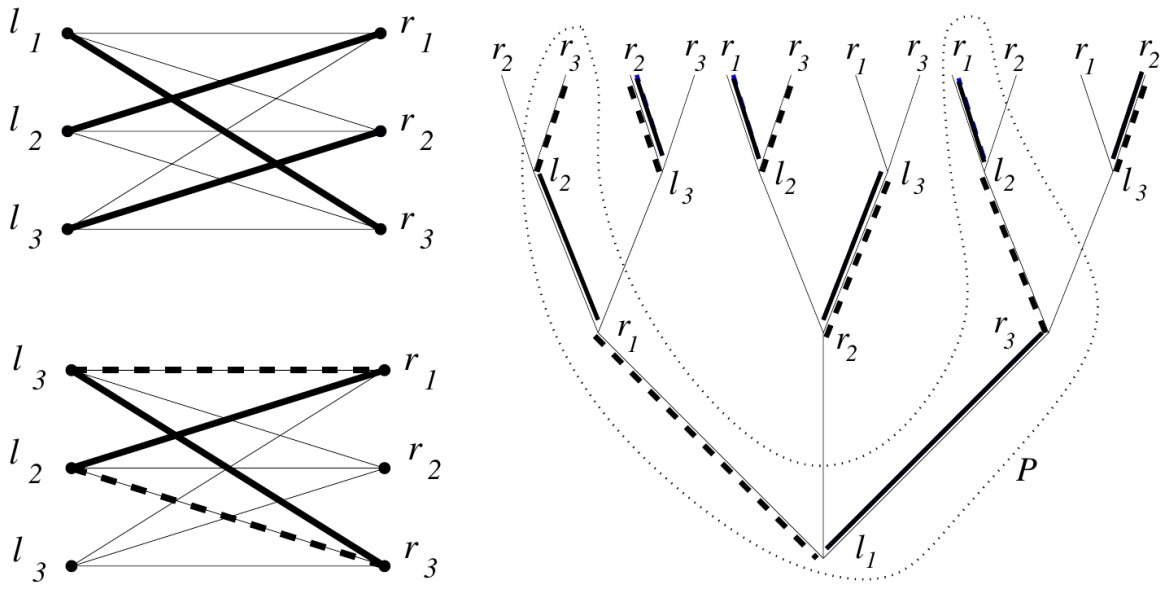


图 16.5: 左上：6 顶点分配实例，粗边为最优匹配。右：根 l_1 的深度 2 计算树，粗边为提升匹配，同一原图边有多个像；虚线为计算树最优内部匹配，圈出的虚线路径为交替路径 P。左下：路径在原图中的投影，本例为一个圈。

译注：原定理用非严格迭代界 $t_*\geq 2NW/\epsilon$，证明末尾则写严格 $>$；这里照录而不自行调整端点。循环分解与余路径闭合在重复顶点及简并情形下也需严谨说明，本翻译不将作者概要升级为独立认证。

[3]简单圈不重复访问同一顶点。

16.3.3 几点说明

随机实例密度演化的唯一不动点为 $a(x) = 1/[4\cosh^2(x/2)]$，从 0 初值确实收敛。另一方面，有限 N 的 W 与最优间隙几乎处处有限，收敛证明意味着最优匹配边上的消息趋于 $+\infty$，其余趋于 $-\infty$。两者如何相容?

密度演化是在固定迭代数、$N \to \infty$ 时预测消息分布；发散发生在 NW/ϵ 尺度。均值 N 指数代价的典型间隙为 $\Theta(1)$，$W = \Theta(N \log N)$，所以原文估计发散在 $t_* = \Theta(N^2 \log N)$ 次后出现。两种分析对应完全不同的极限区域。

16.4 组合结果

直接组合分析可证明随机分配的若干非渐近结果。技巧虽特殊，结果十分优美，也严格证明了前面的 $\zeta(2)$ 代价。这里取速率 1 的独立指数边权；一般速率 α 的密度为 $\alpha e^{-\alpha x}$ $(x \ge 0)$，均值为 $1/\alpha$，尾概率为 $e^{-\alpha x}$。它们特别方便，因为独立指数变量的最小值仍为指数变量。使用以下加强版本。

引理 16.3. *独立指数变量 $X_1, \dots, X_n$ 的速率为 $\alpha_1, \dots, \alpha_n$。则 $X = \min_i X_i$ 的速率为 $\alpha = \sum_i \alpha_i$；取得最小值的指标 I 独立于 X，且 $\mathbb{P}(I = i) = \alpha_i/\alpha$。*

证明. 最小值几乎处处唯一。对 $x \ge 0$，直接计算

$$\begin{aligned}\mathbb{P}(I = i, X \ge x) &= \int_x^\infty \alpha_i e^{-\alpha_i z} \prod_{j \ne i} \mathbb{P}(X_j \ge z)\, dz \\ &= \int_x^\infty \alpha_i e^{-\alpha z}\, dz = \frac{\alpha_i}{\alpha} e^{-\alpha x}. \end{aligned} \tag{16.26}$$

对 i 求和得 X 的尾分布；令 $x = 0$ 得 I 分布，再由乘积分解得独立性。 □

16.4.1 Coppersmith–Sorkin 公式与 Parisi 公式

组合方法依赖规模递归，故推广至不等大小集合的部分匹配。设 $|A| = M, |B| = N$；k-分配是恰有 k 条互不接触边的匹配，最优者使边权总和最小。原问题是 $k = M = N$。以下不失一般性设 $k \le M \le N$。

定理 16.4 (Coppersmith–Sorkin 公式)**.** *独立速率 1 指数代价下，最优 k-分配的期望代价为*

$$C_{k,M,N} = \sum_{i,j=0}^{k-1} \frac{\mathbb{I}(i + j < k)}{(M - i)(N - j)}. \tag{16.27}$$

推论 16.5 (Parisi 公式)**.** *$M = N = k$ 的完美匹配期望代价为*

$$C_N = \sum_{i=1}^{N} \frac{1}{i^2}. \tag{16.28}$$

因此大 N 极限为 $\zeta(2)$。

证明. 由 C–S 公式，相消后 $C_{N+1}-C_N$ 为

$$\sum_{j=0}^{N}\frac{1}{(N+1)(N+1-j)}+\sum_{i=1}^{N}\frac{1}{(N+1-i)(N+1)} -\sum_{r=1}^{N}\frac{1}{(N+1-r)r}. \tag{16.29}$$

用 $1/[(N+1-r)r]=1/[(N+1)r]+1/[(N+1-r)(N+1)]$，原文由此得到 $C_{N+1}-C_N=1/N^2$，完成证明。 □

译注： 所列和直接相消实际得 $1/(N+1)^2$，原末句 $1/N^2$ 下标有误。公式 (16.28) 保留原文正确形式，不据错误差分改动它。

16.4.2 从 k-分配到 $k+1$-分配

证明使用两个引理。记最优匹配为 M_k。第一项只要求不同边子集代价不相同，随机连续代价下以概率 1 满足。

引理 16.6 (嵌套引理)**.** *设 $k<M\le N$，且边代价不存在系数取 $\{+1,0,-1\}$ 的线性组合为 0。则属于 M_k 的每个顶点也属于 M_{k+1}。*

译注： 原假设按上下文应排除全零系数组合；源句未显式写“非平凡”，此处保留原措辞。

记匹配涉及的行列为 $i_1,\dots,i_k$ 及 $j_1,\dots,j_k$，相应 $k\times k$ 子矩阵为 A_k。嵌套引理说下一矩阵仅增加一行一列。原文随后记为 $E^{(1)}\subset E^{(2)}\subset\cdots\subset E^{(M)}=E$，包含全部最优匹配序列。**译注：** 若 $M<N$，最后子矩阵为 $M\times M$，并非整个 $M\times N$ 矩阵；原末等号照录。

证明. 把 M_k 边涂红、M_{k+1} 边涂蓝，考虑并图 G_{k+}，最大度至多 2，连通分量为圈或路径。

不可能有交替圈。设红边为 $u_1,\dots,u_p$，蓝边为 $v_1,\dots,v_p$。M_k 最优意味着红代价不高于蓝，否则交换可改进；M_{k+1} 最优反向推出蓝不高于红。因此两者相等，违反非简并性。

剩下互不相交交替路径，每条红蓝数差至多 1。也不能有红蓝数相等的偶长路径：同样的交换论证会破坏一个最优性。再排除红边多 1 的奇长路径 P：由于总蓝边比红多，必有蓝边多 1 的另一奇长路径 P'。对 $P\cup P'$ 作相同等大小交换，又违反非简并性及最优性。

因此对称差只剩一条蓝边多 1 的奇长路径，两端分别在 A,B，是新增的两个顶点；没有原匹配中出现却在新匹配中消失的顶点。 □

译注： 并图中两匹配共有的边可作为平凡共同分量，应先略去后讨论交替路径；原证明在中途转用对称差，这里按其论证保留，不把共有边误删出匹配本身。

引理 16.7. *给定正数 u_i,v_j，边代价独立且 E_{ij} 的指数速率为 u_iv_j。最优 k-分配的顶点集为 A_k,B_k，新增顶点为 $I_{k+1}=A_{k+1}\setminus A_k$、$J_{k+1}=B_{k+1}\setminus B_k$。则条件概率为 Q_{ij}，其中*

$$Q_{ij}=\frac{u_iv_j}{(\sum_{i'\in A\setminus A_k}u_{i'})(\sum_{j'\in B\setminus B_k}v_{j'})}. \tag{16.30}$$

证明. 由嵌套引理，新匹配或包含 (I_{k+1}, j_b) 及 (i_a, J_{k+1})，其中 $i_a \in A_k, j_b \in B_k$；或包含 (I_{k+1}, J_{k+1})。

固定 i_a, j_b，对第一事件 $E_1(i_a, j_b) = \{A_k, B_k, (I_{k+1}, j_b), (i_a, J_{k+1}) \in M_{k+1}\}$ 取条件。必有 $E_{I_{k+1}, j_b} = \min_{i \in A \setminus A_k} E_{ij_b}$，否则可换更便宜的新增行；另一方向类似。两组独立变量的最小值给出独立新增指标。由指数引理，条件概率为

$$\mathbb{P}(I_{k+1} = i, J_{k+1} = j \mid E_1) = \frac{u_i v_{j_b}}{\sum_{i' \notin A_k} u_{i'} v_{j_b}} \frac{u_{i_a} v_j}{\sum_{j' \notin B_k} u_{i_a} v_{j'}} = Q_{ij}.$$

第二事件 $E_2 = \{A_k, B_k, (I_{k+1}, J_{k+1}) \in M_{k+1}\}$ 下，入选边必为未用行列块的最小值，否则可改进。再用指数引理，概率为 $u_i v_j / \sum_{i' \notin A_k, j' \notin B_k} u_{i'} v_{j'} = Q_{ij}$。每类事件都得同一概率，取它们的并、即只对 A_k, B_k 条件化，仍得结论。 □

译注： 原证明在依赖全局最优匹配事件的条件下直接沿用未条件化指数变量的最小值性质；所需条件独立性 / 选择偏差消除没有在本段展开。这里完整保留其论证强度，不将它作为独立概率证明认证。

16.4.3 C–S 公式的证明

定义 $D_{k,M,N} = C_{k,M,N} - C_{k-1,M,N-1}$，要证明

$$D_{k,M,N} = \frac{1}{N}\left(\frac{1}{M} + \frac{1}{M-1} + \cdots + \frac{1}{M-k+1}\right). \tag{16.31}$$

由此及基步 $C_{1,M,N-k+1} = 1/[M(N-k+1)]$ 递归即得 C–S 公式；基步是 $M(N-k+1)$ 个速率 1 指数变量的最小值。

设原 $M \times N$ 问题的最优 k-分配代价为 X；删去固定最后一列后，最优 $k-1$ 分配代价为 Y。目标为 $\mathbb{E}(X-Y)$。添加一行独立速率 λ 指数变量，形成 $(M+1) \times N$ 的矩阵 F。令 W 为新行末列边权，$\mathcal{E}$ 为新问题最优 k-分配使用该边的事件。

声称 $\lambda \to 0$ 时 $\mathbb{P}(\mathcal{E}) = \lambda \mathbb{E}(X-Y) + O(\lambda^2)$。若该事件发生，必有 $W + Y < X$，所以

$$\begin{aligned} \mathbb{P}(\mathcal{E}) &\le \mathbb{P}(W + Y < X) = \mathbb{E}[1 - e^{-\lambda(X-Y)}] \\ &= \lambda \mathbb{E}(X-Y) + O(\lambda^2). \end{aligned} \tag{16.32}$$

反之，若 $W < X - Y$ 且新行其余各边代价至少 X，最优匹配必用末边。利用独立性，

$$\begin{aligned} \mathbb{P}(\mathcal{E}) &\ge \mathbb{P}(W < X - Y; E_{M+1,j} \ge X,\ j \le N-1) \\ &= \mathbb{E}\left\{ \mathbb{P}(W < X - Y \mid X, Y) \prod_{j=1}^{N-1} \mathbb{P}(E_{M+1,j} \ge X \mid X) \right\} \\ &= \mathbb{E}[(1 - e^{-\lambda(X-Y)}) e^{-(N-1)\lambda X}] \\ &= \lambda \mathbb{E}(X-Y) + O(\lambda^2). \end{aligned} \tag{16.33}$$

另一方面将证明

$$\mathbb{P}(\mathcal{E}) = \frac{1}{N}\left[1 - \prod_{r=0}^{k-1} \frac{M-r}{M-r+\lambda}\right]. \tag{16.34}$$

把新行顶点记为 α。由前一引理，在尚未进入 M_{k-1} 的条件下，下一步进入概率为 $\lambda/[M-(k-1)+\lambda]$。递归得到未进入的概率为乘积；新行的 N 条边统计等价，因此得式 (16.34)。原文将乘积描述为 $\alpha\notin M_{k-1}$ 的概率，虽乘积上限写为 $k-1$。**译注：**该乘积包含 k 步，对应未进入 M_k；原条件下标有一位偏差，照录并定位。

展开得 $\mathbb{P}(\mathcal{E})=\lambda N^{-1}\sum_{r=0}^{k-1}(M-r)^{-1}+O(\lambda^2)$，与两侧界比较即证递归及 C–S 公式。 $\square$

16.5 练习：多指标分配

RS 腔方法对随机分配的 $\zeta(2)$ 预测由组合分析证实，最小和能求最优也支持其正确性。统计物理学家猜测，广泛的随机组合问题满足 RS，但许多问题不满足。两者界限很微妙。下面以多指标随机分配（MIRA）说明如何发现 RS 不一致，略去技术细节，读者可视为长篇引导练习。

实例有 d 个各含 N 顶点的集合 $A_1,\dots,A_d$，每个 d 元组（超边）$a=(a_1,\dots,a_d)$ 有代价 E_a，占据数 $n_a\in\{0,1\}$。匹配的超边互不接触，即每个顶点 i 有 $\sum_{a:i\in a}n_a\le 1$；完美匹配含 N 条占据超边，要使总代价最小。取均值 N^{d-1} 的独立指数代价：

$$\rho(E)=N^{-d+1}e^{-E/N^{d-1}}\mathbb{I}(E\ge 0). \tag{16.35}$$

可检验此标度使典型最优代价为 $\Theta(N)$，普通分配对应 $d=2$。自然推广概率模型为

$$p(n)=\frac{1}{Z}\prod_{a\in\bigcup_r A_r}\mathbb{I}\left(\sum_{i:a\in i}n_i\le 1\right)e^{-\beta\sum_i n_i(E_i-2\gamma)}. \tag{16.36}$$

此处改用因子图记号：超边对应变量 $i,j\in V$，原顶点对应函数 $a,b\in F$。图有 N^d 个度 d 变量，dN 个函数节点，原文称后者每个度 N。用类似参数化得到

$$h_{i\to a}=\sum_{b\in\partial i\setminus a}x_{b\to i},\qquad x_{a\to i}=-\frac{1}{\beta}\log\left[e^{-\beta\gamma}+\sum_{j\in\partial a\setminus i}e^{-\beta(E_j-h_{j\to a})}\right]. \tag{16.37}$$

大 β,γ 时

$$h_{i\to a}=\sum_{b\in\partial i\setminus a}x_{b\to i},\qquad x_{a\to i}=\min_{j\in\partial a\setminus i}(E_j-h_{j\to a}). \tag{16.38}$$

Bethe 自由熵为

$$\begin{aligned}F[x]=Nd\beta\gamma&+\sum_{a\in F}\log\left[e^{-\beta\gamma}+\sum_{i\in\partial a}e^{-\beta(E_i-\sum_{b\in\partial i\setminus a}x_{b\to i})}\right]\\&-(d-1)\sum_{i\in V}\log\left[1+e^{-\beta(E_i-\sum_{a\in\partial i}x_{j\to a})}\right].\end{aligned} \tag{16.39}$$

译注：完全 d 部超图中约束节点的实际度是 N^{d-1}，仅 $d=2$ 时为 N。式 (16.36) 的软奖励仍为 2γ，而后续一般 d 参数化与常数 $Nd\beta\gamma$ 对应的约定须核对；原文未说明更改。式 (16.39) 最后指数中的 $x_{j\to a}$ 方向 / 指标也与所求和的 $a\in\partial i$ 冲突，照录。

RS 腔方法给出大 N 消息分布

$$A(x)=\exp\left\{-\int\left(x+\sum_{j=1}^{d-1}t_j\right)\mathbb{I}\left(x+\sum_{j=1}^{d-1}t_j\geq 0\right)\prod_{j=1}^{d-1}dA(t_j)\right\}. \tag{16.40}$$

$d=2$ 时化为普通分配的方程。RS 下最优代价为 $E_0=Ne_0+o(N)$，其中

$$e_0=\frac{1}{2}\int\left(\sum_{j=1}^{d}x_j\right)^2\mathbb{I}\left(\sum_j x_j>0\right)\prod_{j=1}^{d}dA(x_j). \tag{16.41}$$

译注： 此前 A 定义为递减尾分布，而这里 dA 用作概率积分测度，存在符号约定冲突；应区分 $-dA$ 与分布函数测度，此处照录。

数值可高精度求解，但 $d\geq 3$ 时这些 RS 预测，尤其最优代价，是错误的。有两项不一致证据：

1. 由 Bethe 自由熵计算有限温度自由能密度 $f(T)=-F/(N\beta)$，再取 $s(T)=-df/dT$。例如 $d=3$ 时，种群动力学结果在 $T<T_{\rm cr}\simeq 2.43$ 给出负熵。有限状态空间的模型熵必非负，因此不可能。

2. 类似前面的局部稳定分析，$d=3$ 的 λ_∞ 在 $T\lesssim 1.6$ 变正，表示候选 RS 解对小扰动不稳定。

$d\geq 3$ 普遍有同样现象。RSB 腔方法会给出更满意预测，原稿指向未确定章节 “??”。

注释

随机最优分配代价的严格上界始于 Walkup（1979） 和 Karp（1987）。Mézard 和 Parisi（1985） 先以复本方法得到 $\zeta(2)$，随后腔解见 Mézard 和 Parisi（1986）、Krauth 和 Mézard（1989）；本章表述更接近 Martin、Mézard 和 Rivoire（2005）。后者研究多指标分配，给出本章引导练习答案及正确 RSB 解。

Aldous（2001） 首先严格证明 $\zeta(2)$，方法可视为腔方法的严格版本。重要先行步骤是证明极限存在，并把它描述为无限树上的最小代价匹配（Aldous，1992）。关于这一 “客观方法” 及收敛的综述见 Aldous 和 Steele（2003）；RS 腔方法中递归分布方程的综述见 Aldous 和 Bandyopadhyay（2005）。

算法方面，分配长期得到充分研究，有基于网络流的高效算法（Papadimitriou 和 Steiglitz，1998）。Bayati、Shah 和 Sharma（2005） 提出第一个 BP 算法，2006 年工作将其简化为本章所述的 $O(N^3)$ 算法，并说明其基本等价于 Bertsekas 拍卖算法（Bertsekas，1988）。周期加漂移停止准则来自 Sportiello（2004），漂移发生时间尺度随规模发散的认识来自 Grosso（2004）。

组合研究始于 Parisi（1998a） 的猜想，Coppersmith 和 Sorkin（1999） 将其推广。同一论文还提供了一个优美的……**译注（来源截断）：** 冻结 PartD 最后一页 PDF87（原 374）在英文 “provides a nice” 处结束，句子及注释未完；PartE 直接从第 18 章开始。本译稿保留这一真实缺口，未从其他版本补造续句。

第十八章　布尔变量线性方程

有限域 $\mathbb{F}$ 上线性方程组的求解，是数学最基本的运算之一。有多种多项式算法，最著名的是 Gauss 消元，复杂度 $O(N^3)$，这里 N 为变量数，方程数 $M=\Theta(N)$。还可进一步改善：原稿所述一般系统的最好算法复杂度为 $O(N^{2.376\cdots})$，特殊实例类也有更快方法。

解集是 $\mathbb{F}^N$ 的仿射子空间，看似简单，其几何却可能很丰富。编码理论系统利用这一点：线性码只是有限域上线性空间，却能在无记忆对称信道达到 Shannon 容量，结构并不平凡，见第 11 章。另一方面，线性系统也是约束满足问题：判定是否有解、计算解数都可多项式完成，而最小化违反方程数的优化问题是 NP 困难的。

本章研究 $\mathbb{Z}_2$ 上一类随机系统及其解集结构，系综定义受其他随机约束问题启发，称异或可满足性（XORSAT）。第 18.1 节给出定义、线性代数事实及 SAT–UNSAT 阈值。第 18.2 节研究 BP、关联结构，第 18.3 节联系因子图 2-核；第 18.4、18.5 节由此求阈值并刻画解空间。许多结论可严格推导，XORSAT 也提供理解非严格腔方法的理想练习场，见第 18.6 节。

18.1　定义与一般说明

18.1.1　线性系统

令 H 为 $M\times N$ 二元矩阵，b 为 M 维二元向量。实例是 (H,b)，判定问题要求找 $x\in\{0,1\}^N$ 使 $Hx=b\pmod 2$，或证明无解。模 2 求和等价于异或；有解称 SAT，否则称 UNSAT。解集记为 S，大小 $Z=|S|$，其均匀测度为

$$\mu(x)=\frac{1}{Z}\mathbb{I}(Hx=b\pmod 2)=\frac{1}{Z}\prod_{a=1}^{M}\psi_a(x_{\partial a}). \tag{18.1}$$

∂a 为第 a 行非零位置集，$\psi_a=\mathbb{I}(x_{i_1(a)}\oplus\cdots\oplus x_{i_K(a)}=b_a)$。上下文清楚时略去模 2 说明。

若 H 每行有 p 个非零元，则与 p-自旋玻璃有关。令 $\sigma_i=1-2x_i, J_a=1-2b_a$，能量为

$$E(\sigma)=\sum_{a=1}^{M}\left(1-J_a\prod_{j\in\partial a}\sigma_j\right). \tag{18.2}$$

它等于被违反方程数的两倍。XORSAT 判定是否存在零能自旋构型，即模型是否无阻挫。若有，$\log Z$ 是基态熵。MAX-XORSAT 则最大化满足方程数，或最小化此能量。下面采用 XORSAT 语言，但各结论都有 p-自旋玻璃的对应。

回顾线性代数事实：

1. H 的像维数为 $\operatorname{rank}H$，即独立行数；齐次解空间 $S_0=\ker H$ 维数为 $N-\operatorname{rank}H$。

2. 若 $M \le N$ 且行满秩，任意 b 都有解。

3. 若秩小于 M，则有解当且仅当 b 在 H 的像中。

若有一解 x^*，则 $S = x^* + S_0$，是维数 $N - \operatorname{rank} H$ 的仿射空间，$Z = 2^{N-\operatorname{rank} H}$。齐次均匀测度为

$$\mu_0(x) = \frac{1}{Z_0}\mathbb{I}(Hx = 0 \pmod 2) = \frac{1}{Z_0}\prod_{a=1}^{M}\psi_a^0(x_{\partial a}). \tag{18.3}$$

齐次系统总有全零解，故 μ_0 总有定义，而 μ 只在 SAT 时有定义。线性结构有重要后果：若 y 是非齐次解，$x \sim \mu_0$，则 $x \oplus y \sim \mu$；在 μ_0 下，一个变量或在全部解中冻结为 0，或在一半解中为 0、一半为 1，称自由变量。非齐次情形还可冻结为 1。

习题 18.1. 令 $f : \{0,1\}^N \to \{0,1\}$ 为线性函数，即某些比特的模 2 和。

(a) 若 $x \sim \mu_0$，且存在支撑集内构型使 $f(x) = 1$，证明 f 的两值各有概率 $1/2$；否则它恒为 0。

(b) 若非齐次系统有解且 $x \sim \mu$，证明 $f(x) = 0$ 的概率只能是 $1, 1/2, 0$。

特别取 $f(x) = x_i$ 就得到单比特边缘的结论。

习题 18.2. 证明：

(a) 若齐次解数 $Z_0 = 2^{N-M}$，则任意 b 的非齐次系统都有 2^{N-M} 个解；

(b) 若 $Z_0 > 2^{N-M}$，则只有比例 $2^{N-M}/Z_0$ 的 b 使非齐次系统 SAT。

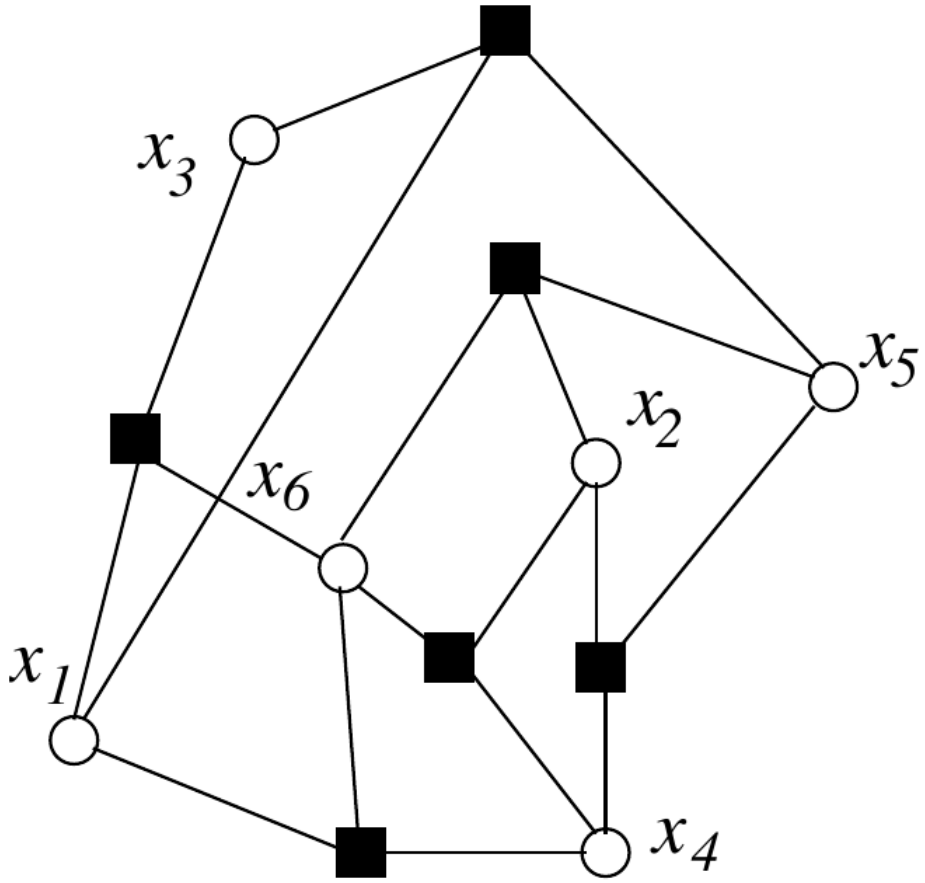


图 18.1: $N = M = 6$ 的 3-XORSAT 实例因子图。

测度的因子图以变量为变量节点、方程为函数节点。公式 $F = (H, b)$ 的图记为 $G(F)$。有些子图可充当 SAT 或 UNSAT 的见证，即其存在蕴含相应结论。简单 UNSAT 见证与 XORSAT 的多项式性质密切相关：选取子句子集 L，保留这些子句、所有邻接变量及相连边；若每个变量度均为偶数，而 $\bigoplus_{a\in L} b_a = 1$，则相加得到矛盾，$L$ 是 UNSAT 见证。这样的图称阻挫超环，类似自旋玻璃中的阻挫环。

习题 18.3. *考虑 3-XORSAT 矩阵*

$$H = \begin{bmatrix} 0 & 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \end{bmatrix}. \tag{18.4}$$

(a) 求秩并列出齐次系统全部解。

(b) 证明原题写的 “$Hb = 0$ 有解” 当且仅当 $b_1 \oplus b_4 \oplus b_5 \oplus b_6 = 0$；此时有多少解？

(b) 考虑图 *18.1*，证明每个齐次解对应变量子集 U，其诱导、并包含所有相邻函数的子图在函数节点处度为偶数。找出一个这样的子图。

译注：原题第二项把待解系统写成 $Hb=0$，按上下文应核对 $Hx=b$；两项重复标 (b)，均按源保留。

18.1.2 随机 XORSAT

随机 K-XORSAT 取 b 在 $\{0,1\}^M$ 均匀，H 在每行恰有 K 个非零元的二元矩阵中均匀抽取；原文这里将矩阵大小写为 $N\times M$。每个方程独立均匀选择 K 个不同变量，因子图服从 $G_N(K,M)$。另一系综将每种可能的行独立以概率 $p=N\alpha/\binom{N}{K}$ 纳入，图服从 $G_N(K,\alpha)$。

齐次系综按相同方式抽 H、固定 $b=0$。它总 SAT，故也称 SAT K-XORSAT，或铁磁 K-自旋模型。记 F_0 为公式 F 对应的齐次公式。

考虑 $N,M\to\infty$、$\alpha=M/N$ 固定。对 $K\geq 3$，Friedgut 定理给出锐阈值序列 $\alpha_s^{(N)}(K)$：当 $\alpha>(1+\delta)\alpha_s^{(N)}$，SAT 概率趋于 0；小于 $(1-\delta)\alpha_s^{(N)}$ 时趋于 1。**译注：**本段矩阵尺寸与前文行列约定相反，保留并定位；仍以前面定义 M 方程、N 变量为准。

阈值是 $\Theta(1)$，可用两简单界说明。由习题 18.2，SAT 概率等于 $2^{N-M}\mathbb{E}(1/Z_0)\leq 2^{-N(\alpha-1)}$，故阈值不大于 1。若 $\alpha<1/[K(K-1)]$，图以高概率由有限树及单环分量组成，矩阵可按分量分块。读者可证明 $K\geq 3$ 时每个这样的块均行满秩，故整体满秩，阈值不小于 $1/[K(K-1)]$。

习题 18.4. $K=2$ 时无锐阈值。

(a) 令 $c(G)$ 为图的圈秩，即边数减顶点数再加分量数，证明 *SAT* 概率为 $\mathbb{E}2^{-c(G)}$。

(b) 说明任意 $\alpha>0$ 时此概率与 *1* 有正间隔。

(c) 证明任意 $\alpha<1/2$ 时此概率与 *0* 有正间隔。

提示：回顾第 *9* 章随机图几何性质。

后面将证明阈值序列有极限 $\alpha_c(K)$ 并显式计算。先给两项改进界。

习题 18.5. 改进上界：

(a) 假设对任意 α，大 N 时事件 $Z_0\geq 2^{Nf_K(\alpha)}$ 的概率大于某 $\varepsilon>0$。证明阈值不高于使 $1-\alpha-f_K(\alpha)\leq 0$ 的最小 α，记为 $\alpha^*(K)$。

(b) 证明可取 $f_K(\alpha)=e^{-K\alpha}$，给出 $\alpha^*(3)\simeq 0.941$。求大 K 渐近，如何改善指数 f_K？

习题 18.6. 用一阶矩改进下界。为方便，允许每个方程的 K 个变量独立均匀抽取，不必不同；最后检验返回原系综只带来小变化。

(a) 对正变量 Z 证明 $(\mathbb{E}Z)(\mathbb{E}[1/Z])\geq 1$，推出 *SAT* 概率不低于 $2^{N-M}/\mathbb{E}Z_{F_0}$。

(b) 证明

$$\mathbb{E}Z_{F_0}=\sum_{w=0}^{N}\binom{N}{w}\left\{\frac{1}{2}\left[1+\left(1-\frac{2w}{N}\right)^K\right]\right\}^M. \tag{18.5}$$

(c) 令 $g_K(x)=\mathcal{H}(x)+\alpha\log\{[1+(1-2x)^K]/2\}$，$\alpha_*(K)$ 为使它在 $x=1/2$ 达到最大值的最大 α，证明阈值不低于 $\alpha_*(K)$。有 $\alpha_*(3)\simeq 0.889$。

18.2 信念传播

18.2.1 BP 消息与密度演化

解上均匀测度是图模型，自然可用消息传递。看似偏离求阈值的目标，实际上会给出重要洞见。先假设非齐次系统 SAT，研究齐次测度 μ_0，再转到 μ。BP 为

$$\nu_{i\to a}^{(t+1)}(x_i)\cong\prod_{b\in\partial i\backslash a}\widehat{\nu}_{b\to i}^{(t)}(x_i),\qquad \widehat{\nu}_{a\to i}^{(t)}(x_i)\cong\sum_{x_{\partial a\backslash i}}\psi_a^0(x_{\partial a})\prod_{j\in\partial a\backslash i}\nu_{j\to a}^{(t)}(x_j). \tag{18.6}$$

线性结构使其大幅简化：单比特或冻结 0、或自由。若初始消息也只取均匀分布（记 $*$）或集中于 0 的分布（记 0），以后仍只取这两类。规则就是擦除解码：变量输出除非全部输入为 $*$，否则为 0；函数输出除非全部输入为 0，否则为 $*$。度 1 变量的输出始终为 $*$。

规则保持自然偏序：若在第二套消息中为 0 的每条边，在第一套中也为 0，就称第一套不弱于第二套。某时刻如此，后续始终如此。因此关注两个极端初值：全 $*$ 或全 0。大 N 极限下，时刻 t 携带 0 的边比例 Q_t 为确定量，满足

$$Q_{t+1}=1-\exp(-K\alpha Q_t^{K-1}). \tag{18.7}$$

全 0 初值为 $Q_0=1$，全 $*$ 为 $Q_0=0$。全 $*$ 永远是不动点；全 0 出发则当 $\alpha<\alpha_d(K)$ 时 $Q_t\to 0$，超过它时趋于方程 $Q=1-e^{-K\alpha Q^{K-1}}$ 的最大正根。原阈值定义为

$$\alpha_d(K)=\sup\{\alpha:\forall x\in(0,1],\ x<1-e^{-K\alpha x^{K-1}}\}. \tag{18.8}$$

译注：原阈值定义的不等号方向与前述迭代相反，而且 $x=1$ 时严格小于不可能成立；按源保留，不暗中反向。对应数值仍按源为 $K=3,4,5$ 时 0.818469、0.772280、0.701780，大 K 时为 $(\log K/K)[1+o(1)]$。

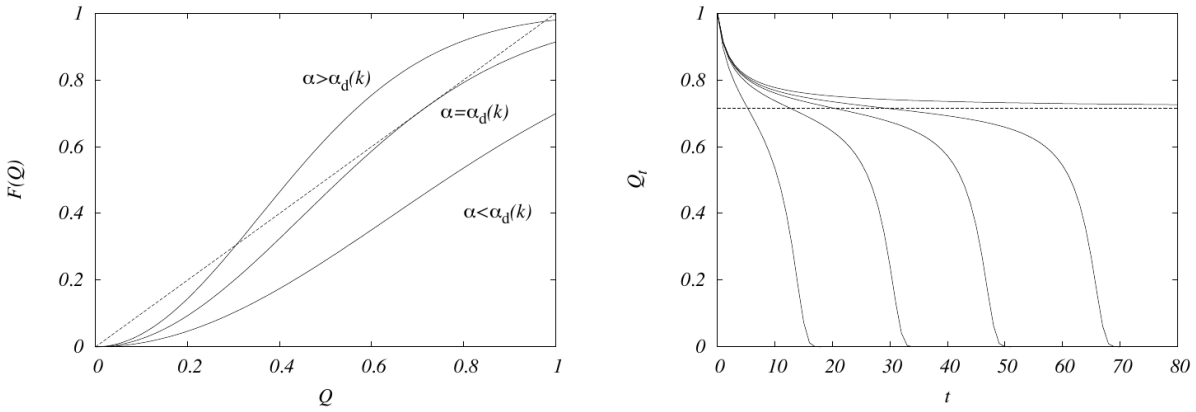


图 18.2: 3-XORSAT 的 0 消息比例密度演化。左：$F(Q)=1-e^{-K\alpha Q^{K-1}}$ 在临界点 $\alpha_d(K=3)\simeq 0.818468$ 下、上及临界处。右：从下到上为 $\alpha=0.75,0.8,0.81,0.814,0.818468$ 的 Q_t。

因此低于 α_d 时，齐次随机问题只有全 $*$ 不动点[1]，BP 预测每比特均匀。高于它时至少有两个不动点：全 $*$ 及原文称 “$*$ 密度为 Q” 的点。非齐次 SAT 区中，给定一解 $x^{(*)}$，由齐次不

[1]论证本身不排除消失比例的 0 消息；更长的计算可以排除。

动点构造

$$\begin{aligned} \nu^{(*)}_{j\to a}(x_j=0)=\nu^{(*)}_{j\to a}(x_j=1)=1/2 \qquad & \text{若}\nu_{j\to a}=*, \\ \nu^{(*)}_{j\to a}(x_j)=\mathbb{I}(x_j=x_j^{(*)}) \qquad & \text{若}\nu_{j\to a}=0, \end{aligned} \tag{18.9}$$

带帽消息同样变换，即得非齐次不动点。$\alpha<\alpha_d$ 时，非齐次问题以高概率也只有一个不动点，见下题。**译注：**前文 Q 定义为 0 消息比例，此处原句却称 $*$ 比例，照录并标出冲突。

习题 18.7. *给定非齐次 BP 不动点，假设每条消息只可能集中于 0、均匀或集中于 1，并无矛盾：不存在变量同时接收一个强制 0、一个强制 1 的带帽消息。构造齐次问题的非平凡 BP 不动点。*

译注：原题没有明说输入不动点须非平凡；若输入本就是全 $*$，其假设仍满足，不能无条件要求输出非平凡点。保留题意边界。

18.2.2 关联衰减

低于 α_d 时 BP 预测每个比特均匀，且不依赖初值，提示结果正确。下面对齐次系统证明，非齐次由平移得到。均匀选变量 i，取图中半径 t 的球 $B_{i,t}(G)$，将球外全部变量固定为 0。令 $Q_t^{(N)}$ 为此条件下所有解均迫使 $x_i=0$ 的概率。局部图趋于随机树，因此固定 t 有 $Q_t^{(N)}\to Q_t$，初值为 1，参见图 18.3。

若无条件所有解中 $x_i=0$，增加边界条件后更是如此，故

$$\lim_{N\to\infty}\mathbb{P}\{\mu_0(x_i=0)=1\}\le\lim_{N\to\infty}Q_t^{(N)}=Q_t. \tag{18.10}$$

左边不依赖 t，而 $t\to\infty$ 时右边趋于 0，所以除消失比例外全部比特自由。

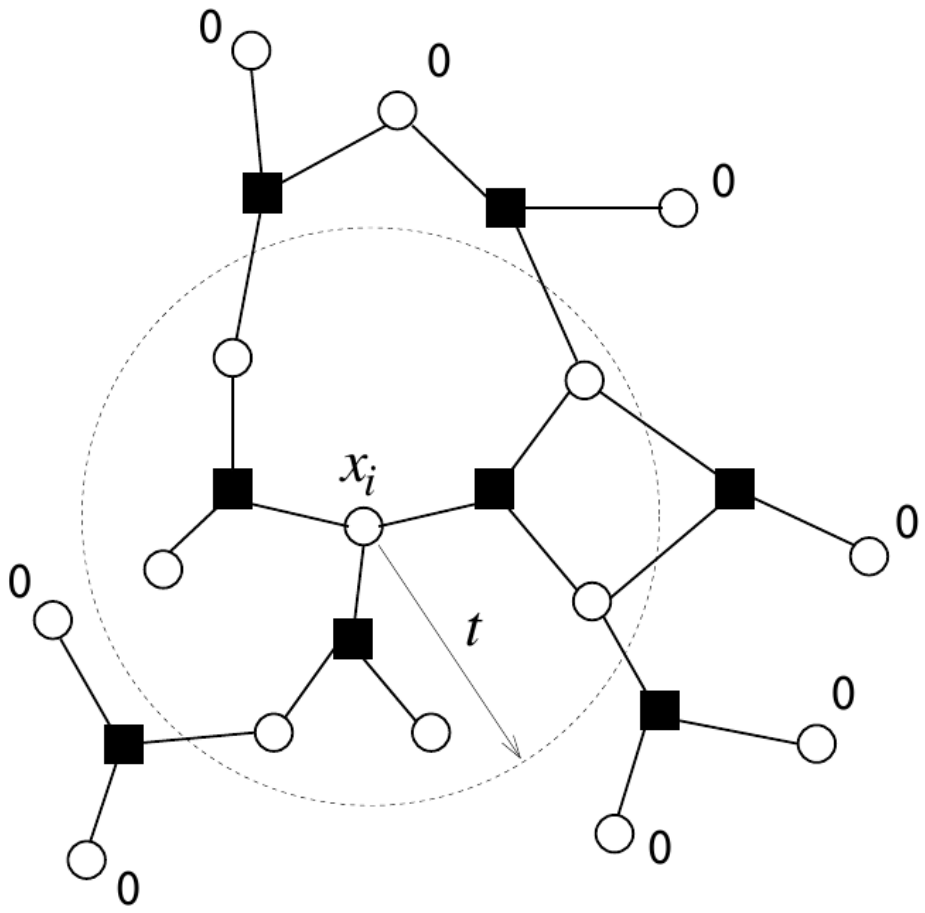


图 18.3: 3-XORSAT 因子图及 i 的深度 1 邻域。将球外变量全固定为 0，并不必然迫使齐次系统的 x_i 为 0。

也可选择任意参考解 $x^{(*)}$，把球外固定为它的值。$Q_t^{(N)}$ 仍描述此时中心变量被迫等于参考值的概率；同样适用于非齐次 SAT 系统。因此 $Q_t \to 0$ 表示中心比特与全部远变量解耦。这里有特殊二分性：远变量或完全确定它，或毫无影响而使它均匀。原文在这一解释中把 “被迫固定的概率” 简写为 “$x_i = x_i^{(*)}$ 的概率”；前者与后者须区别，后者在自由时仍为 $1/2$。

更一般的定义比较两个参考满足解 $x^{(1)}, x^{(2)}$ 所诱导的远处边界，见图 18.4。低于 α_d，最坏情况下仍有

$$\lim_{N\to\infty} \mathbb{E}\left[\sup_{x^{(1)},x^{(2)}} \left|\mu(x_i \mid x^{(1)}_{\sim i,t}) - \mu(x_i \mid x^{(2)}_{\sim i,t})\right|\right] = Q_t \longrightarrow 0. \tag{18.11}$$

译注（可行边界）： 上确界中的两种边界来自满足解，或须限制为条件概率为正的可行边界；任意不可行赋值可能使条件分布无定义。源式保留。第 22 章讨论较弱的非最坏情况衰减定义及其与相变关系。

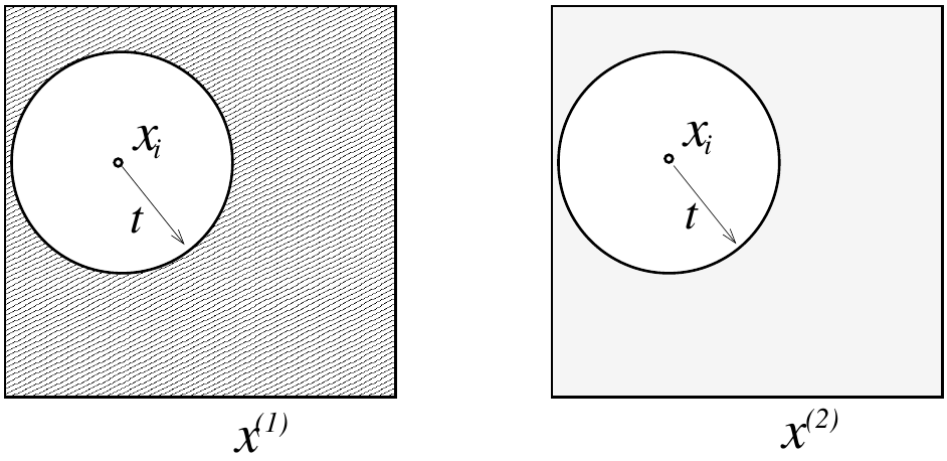


图 18.4: 思想实验：将远离 i 的变量固定为两种不同赋值，检查对 x_i 的影响。$\alpha < \alpha_d$ 时，远边界影响消失。

18.3 核渗流与 BP

18.3.1 2-核与剥离

$\alpha > \alpha_d$ 时发生什么？图 18.1 中全 0 消息是不动点，因为每个变量度至少 2。大随机图在此区域以高概率含同样性质的子图，即 2-核。

第 15 章出现过类似结构，其导致 BEC 迭代解码失败[2]。这里停止集指函数节点子集，其诱导子图中全部变量度至少 2；最大停止集唯一，称 2-核，记 $K_2(G)$。可反复找度 0 或 1 变量（叶），连同其唯一相邻函数（若有）删除，直到无可删节点。剥离也可直接解线性系统：度 1 变量可用其唯一方程以其他变量表示，继而消去。最后得到核系统；原系统有解当且仅当核系统有解，核的解称核解。

18.3.2 团簇

解集可按核上的取值划分。令 $\pi_*(x)$ 为赋值在核变量上的投影。给定核解 $x^{(*)}$，与它关联的团簇 $S(x^{(*)})$ 是满足 $\pi_*(x) = x^{(*)}$ 的全部完整解。若核为空，约定全部解形成一个团簇；此名称的几何意义后面说明。

从核解逆向恢复剥离过程可构造团簇全部解。其中一些变量由核解唯一确定，形成骨架。正式地，令 $B_0(G) = K_2(G)$，每次找尚未纳入、且至少 $K-1$ 个邻接变量已在当前图内的函数节点 a，将它及其邻居加入；无可加节点时停止，得 $B(G)$。结果不依赖加入顺序。骨架包含核，同团簇的任意两解在骨架上相同。

变量因此分为：核中变量、骨架内但不在核中且被核解固定者，以及不由核解唯一决定者。这只依赖图，即矩阵 H，不依赖右端 b。BP 能找出这些结构。

[2]那里是交换变量与函数节点后的对偶因子图的 2-核。

18.3.3 核、骨架与 BP

对齐次问题从全 0 初值运行 BP，至多经过消息总数次迭代便达不动点，证明留给读者。可对迭代归纳验证：

1. 核内每条边的两个方向消息均为 0；
2. 变量在核中，当且仅当收到至少两个相邻函数的 0 消息；
3. 函数若从全部邻居收到 0 消息，就在核内。

骨架变量的条件更简单：当且仅当至少收到一个 0 消息。

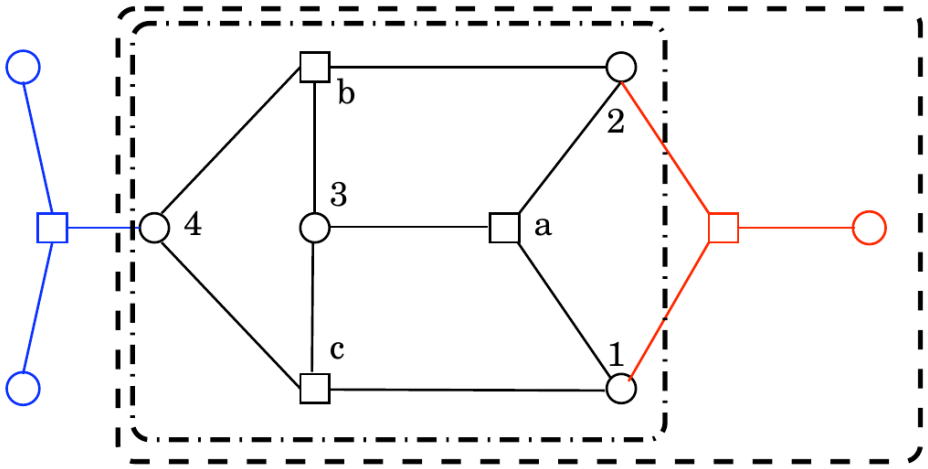


图 18.5: XORSAT 因子图、中央点划线围出的核，以及再加右侧一个函数和变量后得到的骨架（虚线区域）。

习题 18.8. 对图 *18.5*：

(a) 用剥离及骨架构造核实图示结构。

(b) 从全 *0* 初值求齐次 *BP* 不动点，以消息恢复核与骨架。

(c) 对同图非齐次系统，证明核系统有两解：$x_1 = 0, x_2 = b_b \oplus b_c, x_3 = b_a \oplus b_b \oplus b_c, x_4 = b_a \oplus b_b$；及 $x_1 = 0, x_2 = b_b \oplus b_c \oplus 1, x_3 = b_a \oplus b_b \oplus b_c, x_4 = b_a \oplus b_b \oplus 1$。确定两个团簇。

译注： 原题将两套式子都写成 $x_1 = 0$ 并把非核变量列入“核解”，按原保留；独立审校须结合图中边集合核对，未补造缺失取值。

18.4 随机 XORSAT 的 SAT–UNSAT 阈值

核大小的精确刻画给出阈值，且仍可通过 BP 分析获得。

18.4.1 核的大小

从全 0 初值出发，固定 t 的密度演化给出 0 消息比例 Q_t。同一变量的输入消息在大 N 极限独立，0 概率为 $\widehat{Q}_t = Q_t^{K-1}$。暂假设 t, N 极限可交换，则不动点输入仍独立，且

$$Q = 1 - e^{-K\alpha\widehat{Q}}, \qquad \widehat{Q} = Q^{K-1}, \tag{18.12}$$

取最大解。收到 0 消息数趋于均值 $K\alpha\widehat{Q}$ 的 Poisson 变量，至少收到两个才在核中，所以核变量数期望为 $NV(\alpha, K) + o(N)$，其中

$$V(\alpha, K) = 1 - e^{-K\alpha\widehat{Q}} - K\alpha\widehat{Q}e^{-K\alpha\widehat{Q}}. \tag{18.13}$$

核在 α_d 以下为空，到该点跃变为正比例，大 α 时接近全图，见图 18.6。核中度分布是 Poisson 分布条件在至少 2：$\widehat{\Lambda}_0 = \widehat{\Lambda}_1 = 0$，

$$\widehat{\Lambda}_l = \frac{1}{e^{K\alpha\widehat{Q}} - 1 - K\alpha\widehat{Q}} \frac{(K\alpha\widehat{Q})^l}{l!}, \qquad l \geq 2. \tag{18.14}$$

更意外的是，核没有度分布之外的额外结构。

定理 18.1. $G \sim G_N(K, N\alpha)$、$K \geq 3$。则：

(i) $\alpha < \alpha_d$ 时，以高概率 $K_2(G) = \varnothing$；

(ii) $\alpha > \alpha_d$ 时，以高概率 $|K_2(G)| = NV(\alpha, K) + o(N)$；

(iii) 核内度 l 比例在 $\widehat{\Lambda}_l \pm \varepsilon$ 内，概率大于 $1 - e^{-\Theta(N)}$；

(iv) 给定核变量数 n 及其度剖面 $\widehat{\Lambda}$，核服从 $D_n(\widehat{\Lambda}, x^K)$ 系综。

这里不证明。前面已说明主要思想，关键剩下交换两极限：先运行大但固定的 t 次 BP，得到几乎为核的图，再证明序贯剥离在少于 $N\varepsilon$ 步内结束。图 18.7 给出模拟。核出现概率 $P_{\mathrm{core}}(\alpha)$ 从 0 升到 1，随 N 增大转变更锐；令 $\alpha = \alpha_d(K) + \beta(K)zN^{-1/2} + \delta(K)N^{-2/3}$，适当选系数，可证明概率趋于与 K 无关、平滑依赖 z 的非平凡极限。

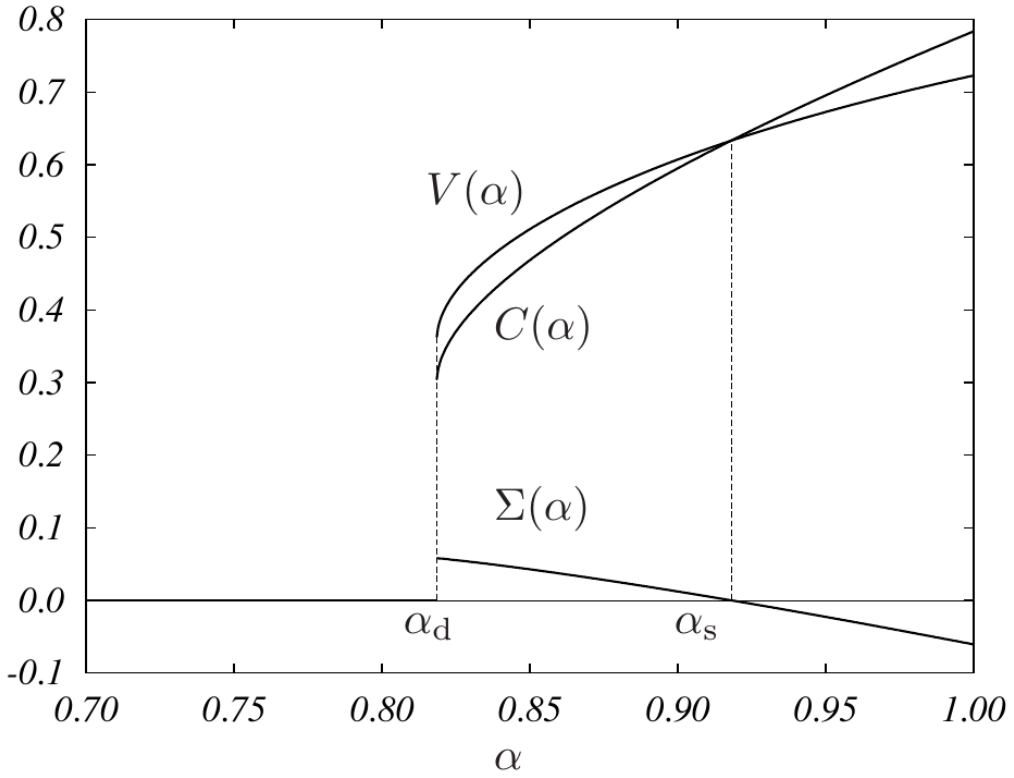


图 18.6: 随机 3-XORSAT 的核变量数 $NV(\alpha)$、方程数 $NC(\alpha)$，及其差 $\Sigma = V - C$。核在 α_d 出现，系统在 $\Sigma(\alpha_s) = 0$ 的阈值以上 UNSAT。原图注将 Σ 直接称为解数，此处保留其符号并指出它实际是单位变量的团簇复杂度指数。

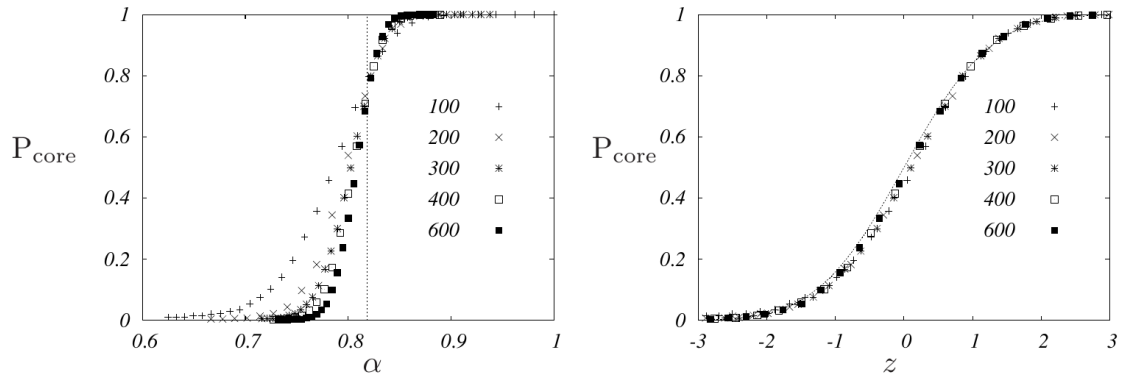


图 18.7: 随机 3-XORSAT 图含 2-核的概率。左：数值与渐近阈值比较。右：按正文变量作尺度图，图例为 $N = 100, 200, 300, 400, 600$。

18.4.2 阈值

核方程数由变量数乘平均度再除 K，为 $NC(\alpha, K) + o(N)$，其中

$$C(\alpha, K) = \alpha \widehat{Q}(1 - e^{-K\alpha\widehat{Q}}). \tag{18.15}$$

低于 α_d 无核；$\alpha_d < \alpha < \alpha_s$ 时核方程数少于变量数，再往上则相反。只要 $C < V$，这些随机方程以高概率独立，得到：

定理 18.2 (XORSAT 可满足性阈值)**.** $K \geq 3$，令

$$\Sigma(K,\alpha) = V(K,\alpha) - C(K,\alpha) = Q - \alpha\widehat{Q}[1 + (K-1)(1-Q)], \tag{18.16}$$

其中 $Q, \widehat{Q}$ 是最大不动点解。定义 $\alpha_s(K) = \inf\{\alpha : \Sigma(K,\alpha) < 0\}$。有 N 变量、$N\alpha$ 方程的随机系统，以趋于 *1* 的概率满足：

(i) $\alpha < \alpha_s$ 时有解；

(ii) $\alpha > \alpha_s$ 时无解；

(iii) $\alpha < \alpha_s$ 时解数为 $2^{N(1-\alpha)+o(N)}$，团簇数为 $2^{N\Sigma(K,\alpha)+o(N)}$。

译注（熵单位）： 上式原文同时以 $2^{N\Sigma}$ 表示团簇数、后文又以 $e^{N\Sigma}$ 表示；而式 (18.16) 的 $\Sigma = V - C$ 以比特计数。这里逐处保留原底数，转换时须包含 $\log 2$。

Σ 最后一式由核方程及不动点条件得到。图 18.8 比较模拟，图 18.9 总结阈值。

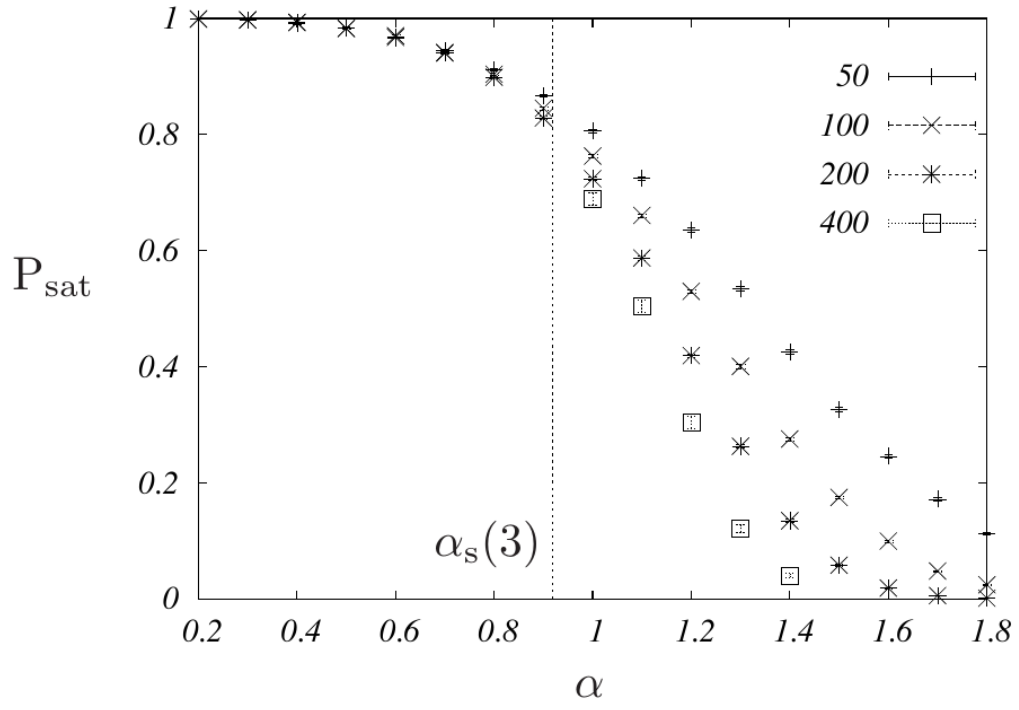
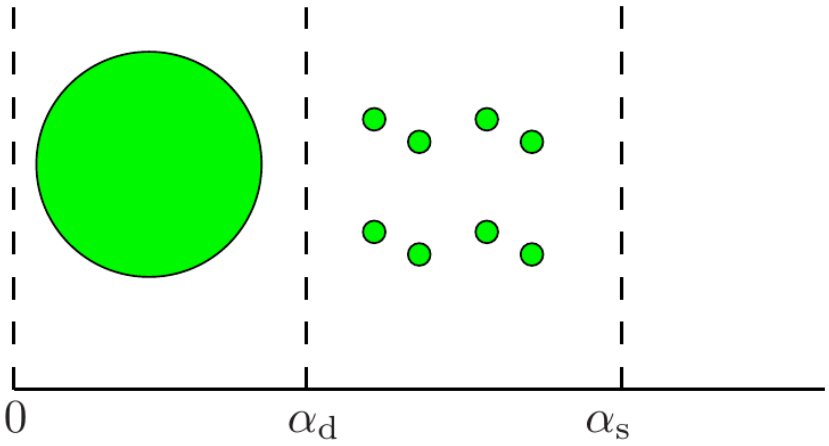


图 18.8: 随机 3-XORSAT 的 SAT 概率，每个参数生成 10^3 至 10^4 实例，图例为 $N = 50, 100, 200, 400$。



K	3	4	5
α_d	0.81847	0.77228	0.70178
α_s	0.91794	0.97677	0.99244

图 18.9: XORSAT 相变图与阈值。$\alpha < \alpha_d$ 为单团簇 Easy-SAT；$\alpha_d < \alpha < \alpha_s$ 为团簇分离的 Hard-SAT；超过 α_s 为 UNSAT。大 K 时 $\alpha_d \simeq \log K/K$，$\alpha_s = 1 - e^{-K} + O(e^{-2K})$。

证明. 只传达基本思想，技术细节见文献。先证 UNSAT 侧。令 H_* 为核的行列子矩阵。若包含某行，所有该行非零列也在其中；故 H 行独立的必要条件是 H_* 行独立，核行数大于列数时不可能。定量地，$M - \operatorname{rank} H \geq \operatorname{rows}(H_*) - \operatorname{cols}(H_*) = -N\Sigma + o(N)$。给定 H，随机右端可解概率为 $2^{\operatorname{rank} H - M}$，故高概率下不大于 $2^{N\Sigma + o(N)}$；$\Sigma < 0$ 时趋于 0。

SAT 侧须证：核行满秩蕴含原矩阵行满秩；阈值以下核以高概率行满秩。第一步由逆剥离得到，每次加回一个含度 1 变量的方程，它独立于此前各式，见图 18.10，所以 $\operatorname{rank} H = \operatorname{rank} H_* + M - \operatorname{rows}(H_*)$，解数因而为 2^{N-M}。

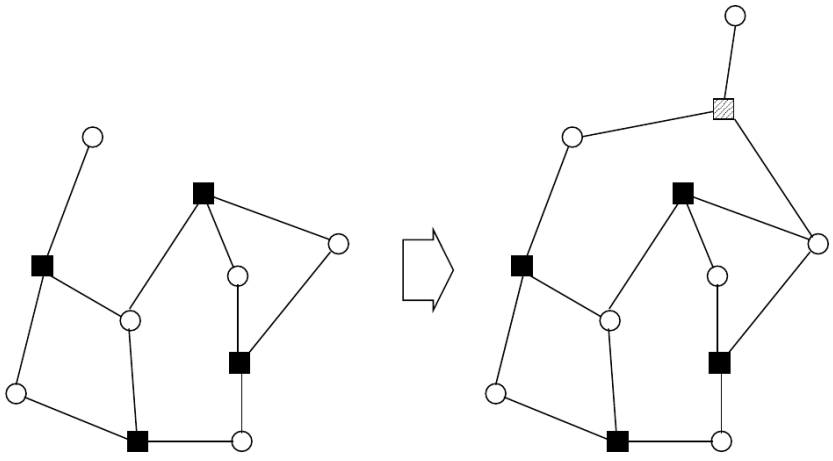


图 18.10: 加入包含度 1 变量的函数节点，对应新方程独立于原有各式。

第二步令核有 n 变量、m 方程，齐次解数为 Z_*。线性代数给出 $Z_* \geq 2^{n-m}$，要证明它高概率恰等于下界。由核随机性，只需在随机度剖面图上分析一阶矩，阈值下有

$$\mathbb{E} Z_* = 2^{n-m}[1 + o_N(1)]. \tag{18.17}$$

原文用 Markov 不等式 $\mathbb{P}(Z_* > 2^{n-m}) \le 2^{-n+m}\mathbb{E}Z_*$ 推出结论。**译注：** 所写上界仅趋于 1，不能直接推出概率趋于 0。利用解数只能按 2 的幂变化，可对归一化超额 $Z_*/2^{n-m}-1$ 再用 Markov，得到所需结论；此说明与原论证区分，不将原缺步隐藏。

令人意外的是该一阶矩如此精确：直接对原系统作同样分析只能达严格低于 α_s 的界；去核后解数涨落大幅减弱。下面只计算领先指数阶，取典型 $n = NV, \Lambda = \widehat{\Lambda}, P(x) = x^K$。这等价于第 11 章核所定义 LDPC 的期望码字数：

$$\mathbb{E}Z_* \doteq \exp\left\{ N \sup_{\omega \in [0, V(K,\alpha)]} \varphi(\omega) \right\}. \tag{18.18}$$

φ 为权重 $N\omega$ 的解数指数，参数表达式为

$$\begin{aligned}
\varphi(\omega) &= -\omega \log x - \eta(1-e^{-\eta})\log(1+yz) \\
&\quad + \sum_{l\ge 2} e^{-\eta}\frac{\eta^l}{l!}\log(1+xy^l) + \frac{\eta}{K}(1-e^{-\eta})\log q_K(z), \qquad (18.19)\\
\omega &= \sum_{l\ge 2} e^{-\eta}\frac{\eta^l}{l!}\frac{xy^l}{1+xy^l}, \qquad (18.20)\\
z &= \frac{\sum_{l\ge 1}(\eta^l/l!)[xy^{l-1}/(1+xy^l)]}{\sum_{l\ge 1}(\eta^l/l!)[1/(1+xy^l)]}, \\
y &= \frac{(1+z)^{K-1}-(1-z)^{K-1}}{(1+z)^{K-1}+(1-z)^{K-1}}. \qquad (18.21)
\end{aligned}$$

其中原文写 $\eta = K\alpha\widehat{Q}_*$，$q_K(z) = [(1+z)^K + (1-z)^K]/2$，且 y, z 随 x 解上式。局部最大值在 $\omega_* = V/2$，$\varphi(\omega_*) = \Sigma \log 2$；只要它是全局最大值，期望即以指数阶等于 2^{n-m}。图 18.11 表明另一局部最大值仅在 $\omega = 0$、函数值 0；所以只要 $\Sigma > 0$，即 $\alpha < \alpha_s$，主导值就是内部点。完整证明仍须估计次指数因子，可以成功完成。 □

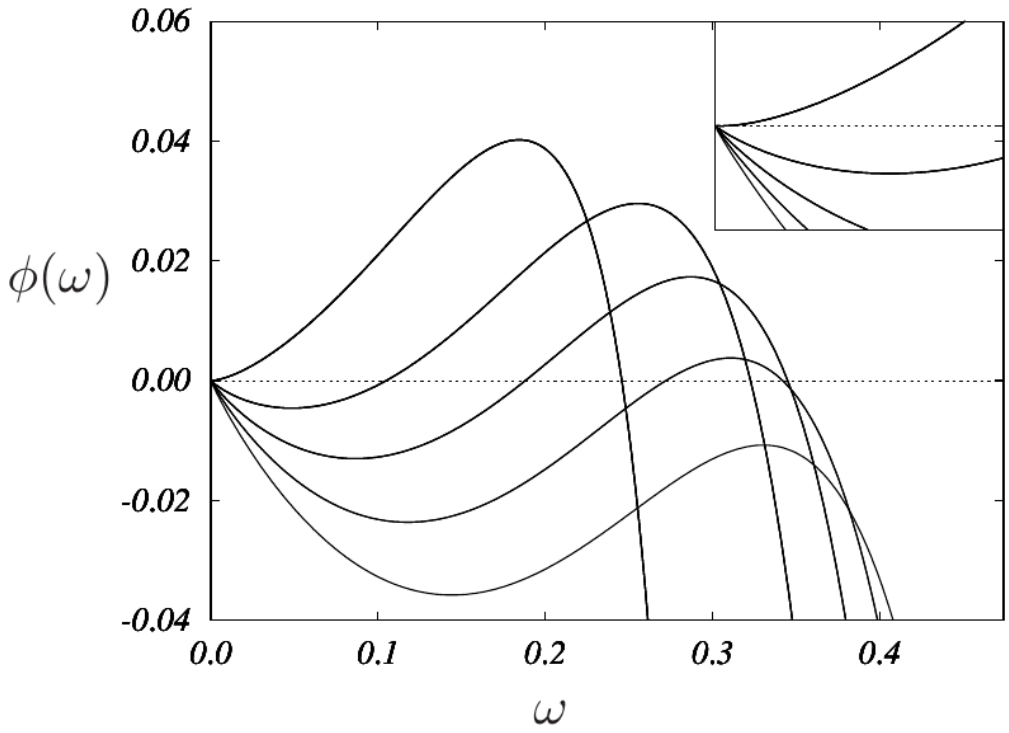


图 18.11: 随机 3-XORSAT 核的权枚举指数。从上到下 $\alpha = 0.818469, 0.85, 0.88, 0.91, 0.94$；$\alpha_s \simeq 0.917935$。原图注还称有小 ω 区域插图，图像按冻结 PDF 保留。

18.5 Hard-SAT 相：解的团簇

整个 $\alpha < \alpha_s$ 区域以高概率有解，解数在原文写作 $Z \doteq e^{N(1-\alpha)}$。解数本身不预示小于 1 的 SAT 阈值，也不显示 α_d 时非空核的突然出现。但 α_d 划分解空间结构及简单算法行为不同的两相。

Easy-SAT 中无核，剥离在期望线性时间找到解，全部解为一团簇。Hard-SAT 中有宏观 2-核，原稿称尚无已知线性时间找解算法；解分为 $2^{N\Sigma+o(N)}$ 个团簇。之前团簇只是核值相同的解子集，下面结果说明不同团簇在 Hamming 空间很远。

命题 18.3. *Hard-SAT 相中存在 $\delta(K,\alpha) > 0$，使以高概率任意不同团簇的两解 Hamming 距离大于 $N\delta$。*

证明. 由权枚举指数，$\alpha > \alpha_d$ 时 $\varphi'(0) < 0$，故某区间 $0 < \omega < \delta$ 有负指数。核的两不同解因此或者距离 $o(N)$，或者距离大于 $N\delta$。原文说明，第一种可沿第 11 章最小距离计算排除。不同团簇核值不同，所以完整解距离至少为核投影距离，故至少 $N\delta$。 □

译注：这是原稿对其核值团簇定义所作的强陈述；指数计算本身并未排除次线性距离，原文在一句中将该步骤交给最小距离分析，不能仅由负指数图像视为完成证明。

因此可把团簇看作相互分离的解块。仍属猜想、未证明的是团簇内部良好连通：任意两解可由一串同团簇解连接，相邻解最多改变 $s_N = o(N)$ 个变量，合理预期为 $\Theta(\log N)$。

18.6 另一种途径：腔方法

前面的随机 XORSAT 分析大量利用了线性结构和非常简单的实例分布。本节给出可推广到更复杂情形的另一种途径；代价是须假设解空间具有某些结构。最终结果与前面所得一致，为这些假设提供了一定可信度。

出发点是：当 $\alpha < \alpha_d(K)$、解集只有一个团簇时，BP 能正确计算解上均匀测度 $\mu(\cdot)$ 的边缘。我们希望将适用范围扩至 $\alpha > \alpha_d(K)$。用 $n \in \{1,\dots,\mathcal{N}\}$ 标记团簇，可将均匀测度分解为各团簇上均匀测度的凸组合：

$$\mu(\cdot) = \sum_{n=1}^{\mathcal{N}} w_n \mu_n(\cdot). \tag{18.22}$$

本例中 $w_n = 1/\mathcal{N}$ 与 n 无关，各 μ_n 可相互平移得到；一般问题则未必如此。

考虑非齐次 XORSAT 系统，令 $x^{(*)}$ 为团簇 n 中一解。若 i 属于骨架，$\mu_n(x_i) = \mathbb{I}(x_i = x_i^{(*)})$；其他节点则有 $\mu_n(x_i = 0) = \mu_n(x_i = 1) = 1/2$。

事实上，每一解 $x^{(*)}$ 都可对应一个 BP 不动点，见式 (18.9)。在此不动点上消息只有三种值：$\nu_{i\to a}^{(*)}(x_i) = \mathbb{I}(x_i = 0)$，简记 $\nu_{i\to a}^{(*)} = 0$；$\mathbb{I}(x_i = 1)$ 简记为 1；两个分量均为 1/2 则简记为 $*$。因子到变量消息也用同样记号。用后者写最简单：

$$\widehat{\nu}_{a\to i}^{(*)} = \begin{cases} 1, & x_i^{(*)} = 1 \text{ 且} i, a \in B(G), \\ 0, & x_i^{(*)} = 0 \text{ 且} i, a \in B(G), \\ , & \text{其他情形.} \end{cases} \tag{18.23}$$

这些消息只依赖 $x^{(*)}$ 在骨架上的值，因而只通过其所属团簇依赖该解。反过来，不同团簇得到不同的不动点。于是将这些不动点记为 $\{\nu_{i\to a}^{(n)}, \widehat{\nu}_{a\to i}^{(n)}\}$，$n$ 为团簇指标。

回顾 BP 不动点条件：

$$\nu_{i\to a} = \begin{cases} *, & \widehat{\nu}_{b\to i} = * \text{ 对所有} b \in \partial i \setminus a, \\ \text{任一非 } * \text{ 的} \widehat{\nu}_{b\to i}, & \text{其他情形,} \end{cases} \tag{18.24}$$

$$\widehat{\nu}_{a\to i} = \begin{cases} *, & \exists j \in \partial a \setminus i \text{ 使} \widehat{\nu}_{j\to a} = *, \\ b_a \oplus \nu_{j_1\to a} \oplus \cdots \oplus \nu_{j_l\to a}, & \text{其他情形.} \end{cases} \tag{18.25}$$

译注：源式 (18.25) 第一分支中的 $\widehat{\nu}_{j\to a}$ 带帽，与变量到因子消息的定义不一致；此处照录。变量更新中“任一”非 $*$ 消息也以这些消息相容为前提；相矛盾的输入会给出无法归一化的零权重。以下把两式符号地写为

$$\nu_{i\to a} = f\{\widehat{\nu}_{b\to i}\}, \qquad \widehat{\nu}_{a\to i} = \widehat{f}\{\nu_{j\to a}\}. \tag{18.26}$$

命题 18.4. *每个团簇 n 可对应一个不同的 BP 方程 (18.25) 的不动点 $\{\nu_{i\to a}^{(n)}, \widehat{\nu}_{a\to i}^{(n)}\}$；当 i, a 属于骨架时，$\widehat{\nu}_{a\to i}^{(n)} \in \{0,1\}$，否则等于 $*$。*

译注（骨架与有向消息）：式 (18.23) 及命题将冻结条件写为 $i, a \in B(G)$，但仅有端点同属骨架并不足以确定有向腔消息。节点边缘冻结不意味着其每个相邻方向的消息都冻结；从核向外传

播的方向须与反向区分。例如取核上的四个三元因子 $a=(1,2,3)$、$b=(1,2,4)$、$c=(1,3,4)$、$d=(2,3,4)$，再接 $e=(1,2,5)$，变量 5 为叶子，所有右端为 0。骨架包含 e 和全部变量，而全 0 参考解对应的 BP 固定点有 $\widehat{\nu}_{e\to1}=\widehat{\nu}_{e\to2}=*$、$\widehat{\nu}_{e\to5}=0$、$\nu_{5\to e}=*$。因此源端点条件不能直接当作完整的方向判据；后文“骨架朝外”的说明须按有向消息理解。这里保留源公式及命题原话，不将其静默替换为另一定理，也不称该例证明了源命题。逆命题不成立：BP 还可能有不属上述类型的解，例如全 $*$ 解，也有图 18.12 所示的非平凡解。

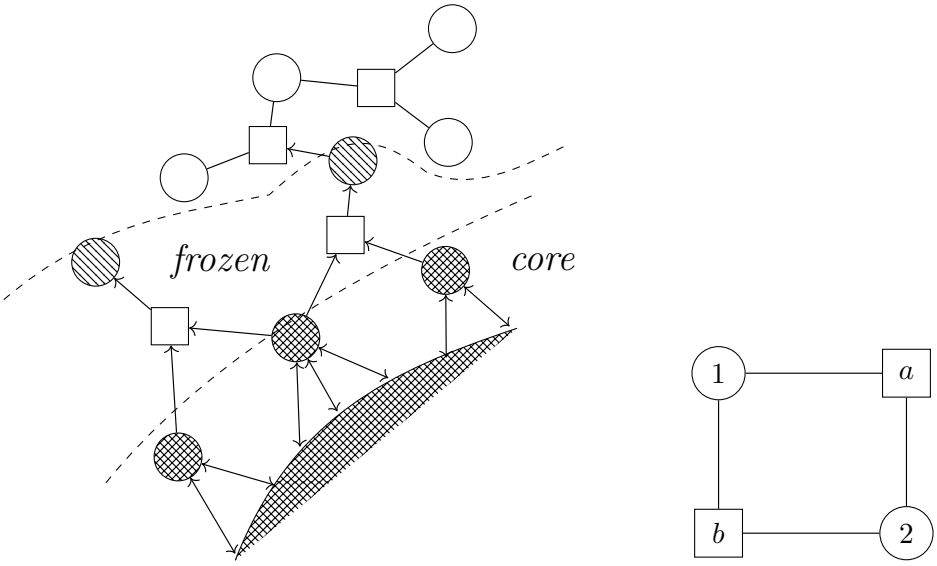


图 18.12: 左：与某团簇 n 对应的一组 BP 消息；箭头表示相应有向消息属于 $\{0,1\}$，其余消息为 $*$。右：小 XORSAT 实例，整个图都是核。齐次问题有两个解 $x_1=x_2=0$ 和 $x_1=x_2=1$，组成两个团簇。除命题 18.4 给出的两个不动点和全 $*$ 不动点外，还存在例如 $\widehat{\nu}_{a\to1}=\nu_{1\to b}=\widehat{\nu}_{b\to2}=\nu_{2\to a}=0$、$\widehat{\nu}_{a\to2}=\nu_{2\to b}=\widehat{\nu}_{b\to1}=\nu_{1\to a}=*$ 的不动点。

第 19 章将一般介绍 1RSB 腔方法；这里先在 XORSAT 特例中作简短、非正式的预览，下章再作较正式的陈述。其前两个假设可概括如下；所有陈述均指以高概率成立。

假设 1。大型随机 XORSAT 实例中，对每个解团簇 n，BP 解 $\nu^{(n)},\widehat{\nu}^{(n)}$ 准确给出测度 $\mu_n(\cdot)$ 的“局域”描述。

例如单点边缘满足

$$\mu_n(x_j)\cong\prod_{a\in\partial j}\widehat{\nu}^{(n)}_{a\to j}(x_j)+o(1).$$

任意有限腔中的局域边缘也由式 (14.18) 良好近似。

假设 2。大型随机 XORSAT 实例在 Hard-SAT 相中有随变量数指数增长的 $e^{N\Sigma}$ 个团簇；BP 方程 (18.25) 的解数在领先指数阶与团簇数相同，特别也与命题 18.4 中构造的解数相同。

原则上可能希望确定每个团簇的整组消息 $\{\nu^{(n)}_{i\to a}\}$。腔方法放弃这一过于宏大的目标，只求固定边 $i\to a$ 上消息在按 $\{w_n\}$ 抽取团簇 n 时的分布，即

$$Q_{i\to a}(\nu)=\mathbb{P}\{\nu^{(n)}_{i\to a}=\nu\},\qquad \widehat{Q}_{a\to i}(\widehat{\nu})=\mathbb{P}\{\widehat{\nu}^{(n)}_{a\to i}=\widehat{\nu}\},\qquad \nu,\widehat{\nu}\in\{0,1,*\}. \tag{18.27}$$

严格计算这些概率仍有困难。为继续，须对随机团簇中消息的联合分布作假设。

最简单的想法是：相距“远”的边上的消息独立。例如进入同一变量 i 的消息，其关联仅由经过 i 的环上的 BP 方程引起；随机 K-XORSAT 的环以高概率长为 $\log N$ 量级，故似乎可认为这些消息渐近独立。但这个假设是错的。若至少两个邻接因子满足 $\widehat{Q}_{a\to i}(0),\widehat{Q}_{a\to i}(1)>0$，独立性将意味着正概率抽到同时有 $\nu^{(n)}_{a\to i}=0$、$\nu^{(n)}_{b\to i}=1$ 的团簇；这种团簇却不存在，因为它不能给 μ_n 下 x_i 的边缘作相容指定。我们假设次简单的情形：以消息彼此不矛盾为条件，它们独立。

假设 3。考虑随机 XORSAT 的 Hard-SAT 相。$i\in G$ 为均匀随机节点，n 按 $\{w_n\}$ 抽取，$\ell\ge 1$ 为整数。距 i 为 ℓ、朝向 i 的全部边 (j,b) 上的消息 $\{\nu^{(n)}_{j\to b}\}$，以相容为条件渐近独立。

“相容”的含义如下：考虑 i 的半径 ℓ 邻域中的线性系统 $H_{i,\ell}x_{i,\ell}=0$；对所有消息属于 $\{0,1\}$ 的边界边施加 $x_j=\nu_{j\to b}$。若此边界条件下有解，便称消息相容。[3]

给定半径 ℓ 邻域边界的消息，式 (18.24)、(18.25) 确定内部消息。考虑半径 ℓ 和 $\ell+1$ 的嵌套邻域，外边界的朝内消息完全决定内边界朝内消息。如果外边界消息服从假设 3，所得内边界消息也满足该假设。两层分布相容，当且仅当单消息边缘满足下列“调查传播”（survey propagation）方程：

$$Q_{i\to a}(\nu)\cong\sum_{\{\widehat{\nu}_b\}}\prod_{b\in\partial i\setminus a}\widehat{Q}_{b\to i}(\widehat{\nu}_b)\,\mathbb{I}(\nu=f\{\widehat{\nu}_b\})\,\mathbb{I}(\{\widehat{\nu}_b\}_{b\in\partial i\setminus a}\in\mathrm{COMP}),\tag{18.28}$$

$$\widehat{Q}_{a\to i}(\widehat{\nu})=\sum_{\{\nu_j\}}\prod_{j\in\partial a\setminus i}Q_{j\to a}(\nu_j)\,\mathbb{I}(\widehat{\nu}=\widehat{f}\{\nu_j\}).\tag{18.29}$$

其中 $\{\widehat{\nu}_b\}\in\mathrm{COMP}$ 当且仅当消息相容，即不同时包含 0 和 1。假设 1–3 只在大系统极限以高概率成立，所以这些等式也应理解为近似：给定任意精度 ε，当 $N\to\infty$ 时以高概率在此精度内满足。

习题 18.9. 证明式 (18.28)、(18.29) 可显式写为

$$Q_{i\to a}(0)\cong\prod_{b\in\partial i\setminus a}[\widehat{Q}_{b\to i}(0)+\widehat{Q}_{b\to i}(*)]-\prod_{b\in\partial i\setminus a}\widehat{Q}_{b\to i}(*),\tag{18.30}$$

$$Q_{i\to a}(1)\cong\prod_{b\in\partial i\setminus a}[\widehat{Q}_{b\to i}(1)+\widehat{Q}_{b\to i}(*)]-\prod_{b\in\partial i\setminus a}\widehat{Q}_{b\to i}(*),\tag{18.31}$$

$$Q_{i\to a}(*)\cong\prod_{b\in\partial i\setminus a}\widehat{Q}_{b\to i}(*).\tag{18.32}$$

$\cong$ 隐含一个整体归一化常数；另有

$$\widehat{Q}_{a\to i}(0)=\frac{1}{2}\left\{\prod_{j\in\partial a\setminus i}[Q_{j\to a}(0)+Q_{j\to a}(1)]+\prod_{j\in\partial a\setminus i}[Q_{j\to a}(0)-Q_{j\to a}(1)]\right\},\tag{18.33}$$

$$\widehat{Q}_{a\to i}(1)=\frac{1}{2}\left\{\prod_{j\in\partial a\setminus i}[Q_{j\to a}(0)+Q_{j\to a}(1)]-\prod_{j\in\partial a\setminus i}[Q_{j\to a}(0)-Q_{j\to a}(1)]\right\},\tag{18.34}$$

$$\widehat{Q}_{a\to i}(*)=1-\prod_{j\in\partial a\setminus i}[Q_{j\to a}(0)+Q_{j\to a}(1)].\tag{18.35}$$

[3]译注：原文此处写齐次右端 0；前文已讨论非齐次实例，应用于后者时还须采用相应的约束右端。本句按源保留。

译注：源题未在式 (18.33)–(18.35) 显式写 b_a；这组 0/1 式采用齐次校验的形式。非齐次且 $b_a=1$ 时，因子输出的 0、1 角色应交换；源式保留。

1RSB 腔方法最后一步是寻找式 (18.28)、(18.29) 的解。对此类解的存在性或数目没有严格结果；而且方程本身只是近似，也须考虑近似解。本例有非常简单、略退化的解，能对全部关心的量给出正确预测。其消息分布只有两类：某些边上 $Q_{i\to a}(0)=Q_{i\to a}(1)=1/2$，略滥用记号简记为 $Q_{i\to a}=0$；其他边上 $Q_{i\to a}(*)=1$，简记 $Q_{i\to a}=*$。$\widehat{Q}$ 同理。简单代数表明，解成立当且仅当原文所谓的 “η” 满足

$$Q_{i\to a}=\begin{cases}*, & \widehat{Q}_{b\to i}=* \text{ 对所有} b\in\partial i\setminus a,\\ 0, & \text{其他情形,}\end{cases} \tag{18.36}$$

$$\widehat{Q}_{a\to i}=\begin{cases}*, & \exists j\in\partial a\setminus i \text{ 使}\widehat{Q}_{j\to a}=*,\\ 0, & \text{其他情形.}\end{cases} \tag{18.37}$$

译注：原文此处突然称 “η” 而未在本段定义，且式 (18.37) 第一分支的变量到因子 $\widehat{Q}_{j\to a}$ 带帽；两处均按源保留。

这些式子与原齐次问题的 BP 方程相同；这是 XORSAT 的特殊性质，不会推广到更进一步的应用。但解释已完全不同：$Q_{i\to a}=0$ 的边上，消息 $\nu^{(n)}_{i\to a}$ 依赖团簇，并在一半团簇中为 0、另一半为 1；这些边位于核内，或位于骨架上但朝核外，见图 18.12。其余边上消息与团簇无关，对所有 n 都为 $*$。

考察单团簇测度下的单比特边缘，可具体理解这些结果。由假设 1，若对所有 $a\in\partial i$ 都有 $\widehat{\nu}^{(n)}_{a\to i}=*$，则 $\mu_n(x_i=0)=\mu_n(x_i=1)=1/2$；若至少一个入消息为 0（或 1），则 $\mu_n(x_i=0)=1$（或 0）。这就恢复前面完整解：给定团簇内骨架变量完全冻结为 0 或 1，其他变量等概率取 0、1。腔方法还可计算复杂度 $\Sigma(K,\alpha)$ 及测度的其他许多性质，下章继续。

注释

随机 XORSAT 最初作为随机可满足性的简单例子见 Creignou 和 Daudé（1999），研究每子句含 $O(N)$ 个变量的 “稠密公式”，其 SAT–UNSAT 阈值为 $\alpha=1$。编码理论中，Elias 在 20 世纪 50 年代已刻画该模型（Elias，1955），参见第 6 章。

Creignou、Daudé 和 Dubois（2003）用矩界研究稀疏公式。Ricci-Tersenghi、Weigt 和 Zecchina（2001）、Franz、Leone、Ricci-Tersenghi 和 Zecchina（2001a）、Franz、Mézard、Ricci-Tersenghi、Weigt 和 Zecchina（2001b）用复本方法得到团簇图像、SAT–UNSAT 阈值并研究团簇相的玻璃性质。

将线性系统化为核后，一阶矩方法能精确刻画 SAT–UNSAT 阈值，这一点由 Cocco、Dubois、Mandler 和 Monasson（2003）及 Mézard、Ricci-Tersenghi 和 Zecchina（2003）两组独立发现。后者还讨论腔方法。完成证明所需的完整二阶矩计算，在 $K=3$ 情形见 Dubois 和 Mandler（2002）。

Montanari 和 Semerjian（2005；2006a）、Mora 和 Mézard（2006）研究随机 K-XORSAT 解集更精细的几何性质；尽管如此，团簇确实 “良好连通” 仍有待证明。

各转变位置已严格确定，自然可问临界窗口。Leone、Ricci-Tersenghi 和 Zecchina（2001）数值研究 SAT–UNSAT 转变的有限尺寸标度。Dembo 和 Montanari（2008a） 精确刻画了对应团簇转变的 2-核出现的有限尺寸标度。

第十九章　一步复本对称性破缺腔方法

信念传播的有效性依赖一个基本假设：从因子图剪掉一个函数节点后，在所得分布中，相邻变量的关联变弱。因子图存在短环，或变量间存在长距离关联，都可能使该假设失效。在局部树状因子图中，BP 的失效由后一种情况引起。长程关联的出现标志着分隔“弱关联”与“强关联”相的相变；后者通常表现为（Boltzmann）概率分布分解成彼此分离的“块”，即纯 Gibbs 态。

随机 XORSAT 提供了一个简单例子。类似图景也见于随机图着色、随机可满足性、自旋玻璃等许多问题。但这类系统中纯态的结构和组织远未充分理解，长程关联与纯态分解的联系也比上述说明更微妙。

尽管如此，物理学家已发展出一种非严格的处理途径：“一步复本对称性破缺”（1RSB）腔方法。它假设纯态分解具有若干性质，据此推导定量预测；从数学观点看，这些是“猜想”，例如随机 K-SAT 及其他随机约束满足问题的可满足性阈值。

该方法也允许对假设作一定自洽性检验。在若干通过检验的例子中，预测得到严格论证的证实；原稿写作时还没有预测被证伪的例子。这些成功推动人们寻求稀疏随机图上 Gibbs 态的数学理论。

本章交替作一般介绍与 XORSAT 具体说明。建议先读前章，建立对整个图景的直觉。第 19.1 节介绍 1RSB 玻璃相和纯态分解；第 19.2 节引入计算 BP 解数的辅助约束满足问题，1RSB 分析就是对辅助问题再次应用 BP，继而可使用第 14 章的密度演化等方法。第 19.3 节用 XORSAT 说明它如何恢复前章的严格结果。第 19.4 节说明辅助问题“温度”取 $x = 1$ 时形式如何大幅简化。第 19.5 节借助最小和算法处理优化，得到调查传播。第 19.6 节解释物理直觉；末尾附录含 XORSAT 调查传播方程及其统计分析的技术细节。**译注：**前文中 x 扮演逆温度，源章导读却称其为温度；此处保留这一用词差异，不混同二者。

19.1　超越 BP：多态

19.1.1　Bethe 测度

前面几章表明，局部树状图模型的分布在许多情形具有相当简单的形式，我们称为 Bethe 测度或 Bethe 态。先说明此名称，再讨论其他可能图景。沿用第 14 章，因子图 $G = (V, F, E)$ 的变量节点为 $V = \{1, \dots, N\}$，因子节点为 $F = \{1, \dots, M\}$，联合分布为

$$\mu(x) = \frac{1}{Z} \prod_{a=1}^{M} \psi_a(x_{\partial a}), \qquad x \in \mathcal{X}^N. \tag{19.1}$$

对变量集 $U \subseteq V$（称“腔”），诱导子图 $G_U = (U, F_U, E_U)$ 包含所有满足 $\partial a \subseteq U$ 的因子节点及其相邻边。若 $i \in U, a \in F \setminus F_U$，记 $(i,a) \in \partial U$。消息集 $\{\widehat{\nu}_{a\to i}\}$ 是由图中有向边 $a \to i$ 标记的一组 $\mathcal{X}$ 上概率分布。

定义 19.1 (非正式). 若存在消息集 $\{\widehat{\nu}_{a\to i}\}$，使对“几乎所有”“有限大小”的腔 U，其变量边缘满足

$$\mu_U(x_U) \cong \prod_{a\in F_U} \psi_a(x_{\partial a}) \prod_{(ia)\in\partial U} \widehat{\nu}_{a\to i}(x_i) + \mathrm{err}(x_U), \tag{19.2}$$

其中误差项“很小”，则称 μ 为 *Bethe* 测度或 *Bethe* 态；$\cong$ 仍表示略去归一化常数。

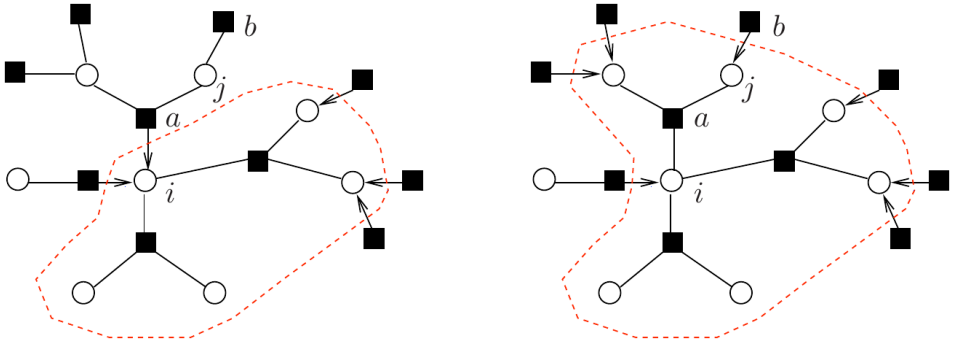


图 19.1: 两个腔的例子。右图比左图多一个函数节点 a；两个腔中的 Bethe 测度相容性蕴含 $\widehat{\nu}_{a\to i}$ 的 BP 方程，见习题 19.1。

正式定义须说明“几乎所有”“有限大小”“很小”。可引入容差 $\varepsilon_N \downarrow 0$ 及在 $N \to \infty$ 时有界的尺寸 L_N，要求在全部 $|U| < L_N$ 的腔中，超过 $1-\varepsilon_N$ 的比例满足误差的某种范数（例如 L^p 范数）小于 ε_N。直觉是给定消息可在局域良好近似 μ。下面沿用物理学习惯，将各种近似误差留作隐含条件。

这个定义没有利用式 (19.1) 的因子分解，因而适用于 $x = \{x_i : i \in V\}$ 上任意分布。若 μ 对某消息集为 Bethe 测度，式 (19.2) 对不同 U 的相容性便约束消息。特别地，若图中环不太短，并对 ψ_a 加一定技术条件，消息须近似满足 BP 方程。称满足几乎全部方程、且误差在一定精度内的消息集为 BP 准解。下题请读者证明这一点。

习题 19.1. 设 G 的围长大于 2，μ 对消息集 $\{\widehat{\nu}_{a\to i}\}$ 为 *Bethe* 测度，且各 $\widehat{\nu}_{a\to i}(x_i) > 0$、$\psi_a(x_{\partial a}) > 0$。对 $U \subseteq V$、$(i,a) \in \partial U$，令 $W = U \cup \partial a$，见图 *19.1*。分别对 U, W 应用式 (19.2)，证明消息在与 err 同阶的误差内满足

$$\widehat{\nu}_{a\to i}(x_i) \cong \sum_{x_{\partial a\setminus i}} \psi_a(x_{\partial a}) \prod_{j\in\partial a\setminus i} \left\{ \prod_{b\in\partial j\setminus a} \widehat{\nu}_{b\to j}(x_j) \right\}. \tag{19.3}$$

证明它们等价于式 (14.14)、(14.15)。提示：定义 $\nu_{k\to c}(x_k) \cong \prod_{d\in\partial k\setminus c} \widehat{\nu}_{d\to k}(x_k)$。

若逆命题也成立，即每个 BP 准解对应不同的 Bethe 测度，将非常理想。这一联系正是 1RSB 假设的核心，但并非总成立。

例 19.2. 设因子图的因子和变量度均为 $K \geq 3$，变量二值，且

$$\psi_a(x_{i_1(a)}, \dots, x_{i_K(a)}) = \mathbb{I}(x_{i_1(a)} \oplus \cdots \oplus x_{i_K(a)} = 0). \tag{19.4}$$

给定完美匹配 $\mathsf{M} \subseteq E$。若 $(i,a) \in \mathsf{M}$，令 $\widehat{\nu}_{a\to i}(x_i) = \mathbb{I}(x_i = 0)$、$\nu_{i\to a}(0) = \nu_{i\to a}(1) = 1/2$；否则令 $\widehat{\nu}_{a\to i}(0) = \widehat{\nu}_{a\to i}(1) = 1/2$、$\nu_{i\to a}(0) = \mathbb{I}(x_i = 0)$（变量到因子）。

检验这是 *BP* 解，且得到的全部局域边缘均与 $\mu(x) \cong \mathbb{I}(x = 0)$ 相同，与匹配无关。例如两侧度均为 $K \geq 3$ 的随机正则图，其完美匹配数以高概率随节点数指数增长；于是指数多个 *BP* 解描述同一个 *Bethe* 测度。

译注：上一例末项在源文把消息左端写为 $\nu_{i\to a}(0)$、右端却依赖 x_i；照录，作为分布应核对左端是否为 $\nu_{i\to a}(x_i)$。

19.1.2 几种一般图景

Bethe 测度是描述式 (19.1) 分布的概念工具。受玻璃相研究启发，统计力学提出几种一般图景：

RS（复本对称） 最简单的情形：μ 本身是 Bethe 测度。稍复杂但仍归入 RS 的是，μ 分解为有限个由全局对称性联系的 Bethe 测度，例如源第 17.3 节的铁磁 Ising 模型。[1]

d1RSB（动力学一步复本对称性破缺） 存在随系统尺寸 N 指数增长的 Bethe 测度，且

$$\mu(x) = \sum_n w_n \mu_n(x), \tag{19.5}$$

各 w_n 随 N 指数小；此外 μ 本身也是 Bethe 测度。

s1RSB（静态一步复本对称性破缺） 同样有指数多个 Bethe 态和凸分解，但 $N \to \infty$ 时有限个权重为 1 的量级，μ 本身不再是 Bethe 测度。

下面统一处理 d1RSB、s1RSB，并合称 1RSB。还可能存在完全 RSB 等更复杂情形，但原稿写作时对稀疏图模型中这些情形的控制较弱，这里不讨论。

继续须对 1RSB 的 Bethe 态结构作假设。它们仍待完全形式化，但已足以导出有意义的定量预测。为免技术困难，设 $\psi_a > 0$，允许零值的情形须视作极限。用 n 标记 BP 准解 $\{\nu^n_{i\to a}, \widehat{\nu}^n_{a\to i}\}$，每个准解对应 Bethe 测度，自由熵为 $F_n = F(\nu^n)$。三个公设如下。

假设 1。BP 有指数多个准解。自由熵 $F(\nu^n) \simeq N\varphi$ 的准解数，在领先指数阶为 $\exp\{N\Sigma(\varphi)\}$；Σ 称复杂度函数。[2]

较正式地，存在 $\Sigma : \mathbb{R} \to \mathbb{R}_+$，对任意 $[\varphi_1, \varphi_2]$，自由熵在 $[N\varphi_1, N\varphi_2]$ 的准解数为 $\exp\{N\Sigma_* + o(N)\}$，其中 $\Sigma_* = \sup_{\varphi_1 \leq \varphi \leq \varphi_2} \Sigma(\varphi)$。还假设 Σ 足够规则，不再详述。

短程关联、即极端的 Bethe 测度特别重要；第 12 章已提及，第 22 章将讨论相应关联衰减。将极端测度集记为 $\mathcal{E}$。

---

[1] 译注：冻结草稿缺第 17 章正文；此交叉引用保留，不能据此声称该章已译。

[2] 这里只关心领先指数行为，故准解定义细节不再重要，只要例如被违反 BP 方程的比例在大 N 极限消失。

假设 2。式 (19.1) 的正则测度可分解为极端 Bethe 测度的凸组合

$$\mu(x)=\sum_{n\in\mathcal{E}} w_n\mu_n(x), \qquad w_n=e^{F_n}/\Xi, \qquad \Xi=\sum_{n\in\mathcal{E}} e^{F_n}. \tag{19.6}$$

假设 1 刻画近似 BP 不动点数，假设 2 则用极端 Bethe 测度表示 μ。由前节论证，每个此类测度产生 BP 不动点，但逆向联系并不明确；下一假设在领先指数阶要求它成立。

假设 3。极端 Bethe 测度数在领先指数阶等于 BP 准解数：自由熵约为 $N\varphi$ 的极端 Bethe 测度数也为 $\exp\{N\Sigma(\varphi)\}$。

19.2 1RSB 腔方程

在以上三个假设内，复杂度给出 μ 如何分解为 Bethe 测度的基本信息。给定自由熵密度的极端 Bethe 测度数随系统尺寸指数增长，自然可用统计物理形式处理：原问题的 BP 消息作新变量，Bethe 测度作新构型，这正是 1RSB 的内容。

引入极端 Bethe 测度上的正则分布，赋予 $n\in\mathcal{E}$ 权重 $w_n(x)=e^{xF_n}/\Xi(x)$。参数 x 扮演逆温度，常称 Parisi 1RSB 参数[3]；广义配分函数为

$$\Xi(x)=\sum_{n\in\mathcal{E}} e^{xF_n} \doteq \int e^{N[x\varphi+\Sigma(\varphi)]}\,d\varphi. \tag{19.7}$$

原测度中的权重为 e^{F_n}/Ξ，故原问题对应 $x=1$；改变 x 可恢复整个复杂度函数。若 $\Xi(x)\doteq e^{N\mathcal{F}(x)}$，鞍点计算给出 Legendre 关系

$$\mathcal{F}(x)=x\varphi+\Sigma(\varphi), \qquad \frac{\partial\Sigma}{\partial\varphi}=-x. \tag{19.8}$$

19.2.1 计数 BP 不动点

为估计 $\Xi(x)$，考察 $w_n(x)$ 在消息 $\nu=\{\nu_{i\to a},\widehat{\nu}_{a\to i}\}$ 上诱导的分布 $P_x(\nu)$。关键观察是它也可写成图模型：变量是 BP 消息，一类因子强制 BP 方程，另一类实现权重 $e^{xF(\nu)}$；辅助因子图拓扑也与原图接近，提示可再次用 BP 估计复杂度。整个途径可概括为：在 Bethe 测度上引入 Boltzmann 分布，把它写成图模型，再用 BP 研究。

须区分原模型和辅助模型及各自消息。原消息改记 $\widehat{\nu}_{a\to i}=\widehat{m}_{ai}$、$\nu_{i\to a}=m_{ia}$，两组消息分别记 $\widehat{m},m$；共 $2|E|$ 个，均为 $\mathcal{X}$ 上归一化概率分布。原 BP 方程为

$$m_{ia}(x_i)\cong\prod_{b\in\partial i\setminus a}\widehat{m}_{bi}(x_i), \qquad \widehat{m}_{ai}(x_i)\cong\sum_{\{x_j\}_{j\in\partial a\setminus i}}\psi_a(x_{\partial a})\prod_{j\in\partial a\setminus i}m_{ja}(x_j), \tag{19.9}$$

$$m_{ia}=f_i(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a}), \qquad \widehat{m}_{ai}=\widehat{f}_a(\{m_{ja}\}_{j\in\partial a\setminus i}). \tag{19.10}$$

[3]这一途径等价于第 12 章克隆方法，其中 x 为克隆数。

每个消息集的权重正比于 $e^{xF(m,\widehat{m})}$，其中

$$F(m,\widehat{m}) = \sum_{a\in F} F_a(\{m_{ja}\}_{j\in\partial a}) + \sum_{i\in V} F_i(\{\widehat{m}_{bi}\}_{b\in\partial i}) - \sum_{(ia)\in E} F_{ia}(m_{ia},\widehat{m}_{ai}). \tag{19.11}$$

$$F_a = \log\left[\sum_{x_{\partial a}} \psi_a(x_{\partial a}) \prod_{j\in\partial a} m_{ja}(x_j)\right],$$

$$F_i = \log\left[\sum_{x_i} \prod_{b\in\partial i} \widehat{m}_{bi}(x_i)\right], \tag{19.12}$$

$$F_{ia} = \log\left[\sum_{x_i} m_{ia}(x_i)\widehat{m}_{ai}(x_i)\right]. \tag{19.13}$$

上式从式 (14.28) 复制以便使用。将这 $2|E|$ 个消息视作辅助图模型变量，诱导分布为

$$P_x(m,\widehat{m}) = \frac{1}{\Xi(x)} \prod_{a\in F} \Psi_a(\{m_{ja},\widehat{m}_{ja}\}_{j\in\partial a}) \prod_{i\in V} \Psi_i(\{m_{ib},\widehat{m}_{ib}\}_{b\in\partial i}) \times \prod_{(ia)\in E} \Psi_{ia}(m_{ia},\widehat{m}_{ia}), \tag{19.14}$$

$$\Psi_a = \prod_{i\in\partial a} \mathbb{I}[\widehat{m}_{ai} = \widehat{f}_a(\{m_{ja}\}_{j\in\partial a\setminus i})]\, e^{xF_a(\{m_{ja}\}_{j\in\partial a})}, \tag{19.15}$$

$$\Psi_i = \prod_{a\in\partial i} \mathbb{I}[m_{ia} = f_i(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a})]\, e^{xF_i(\{\widehat{m}_{bi}\}_{b\in\partial i})}, \tag{19.16}$$

$$\Psi_{ia} = e^{-xF_{ia}(m_{ia},\widehat{m}_{ai})}. \tag{19.17}$$

译注： 源式 (19.14) 的带帽消息指标与前后定义有多处 ia/ai 互换，均照录；一般约定仍为 m_{ia} 与 $\widehat{m}_{ai}$。

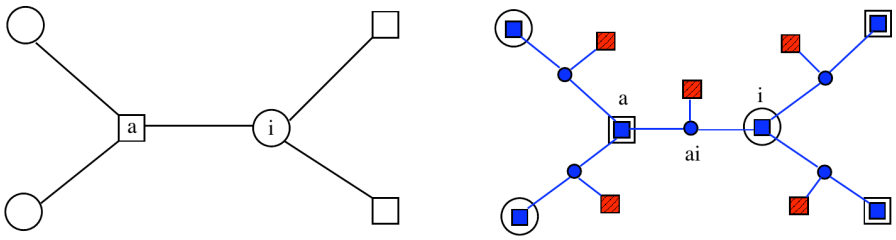


图 19.2: 原因子图的局部（左）与相应辅助因子图（右）。

图 19.2 的辅助图可如下构造：

1. 原图每条边 (i,a) 对应一个变量节点，取值为消息对 $(m_{ia},\widehat{m}_{ai})$；另接一个度 1 函数节点，贡献因子 $\Psi_{ia} = e^{-xF_{ai}}$。

2. 原图每个因子 a 对应一个函数节点，连接全部 $i\in\partial a$ 的边变量。Ψ_a 一方面强制以 m_{ia} 表示 $\widehat{m}_{ai}$ 的 $|\partial a|$ 个 BP 方程，另一方面贡献 e^{xF_a}。

3. 原图每个变量 i 也对应一个函数节点，连接全部 $a \in \partial i$ 的边变量。Ψ_i 强制以 $\widehat{m}_{bi}$ 表示 m_{ib} 的 $|\partial i|$ 个 BP 方程，并贡献 e^{xF_i}。

源文对式 (19.17) 的处理有意略粗略。消息通常连续，示性函数须换成 δ 函数，继而涉及消息上的参考测度以及是否应期待精确 BP 解等定义问题。可将上述形式理解为：先离散化消息和 BP 方程，使消息仅取有限 q 个值；固定 q 取 $N \to \infty$ 计算复杂度，最后再令 $q \to \infty$。也可采用其他同样合理的极限程序，作者预期它们给出相同结果；实践中逐例处理这些歧义。

19.2.2 辅助模型上的消息传递

计算 Bethe 测度数、较准确说计算复杂度，已化成估计辅助模型配分函数 $\Xi(x)$。原图局部树状时辅助图也局部树状，因此用 BP 估计自由熵密度 $\mathcal{F}(x) = \lim_N N^{-1}\log\Xi(x)$，再由式 (19.8) 的 Legendre 变换得复杂度。

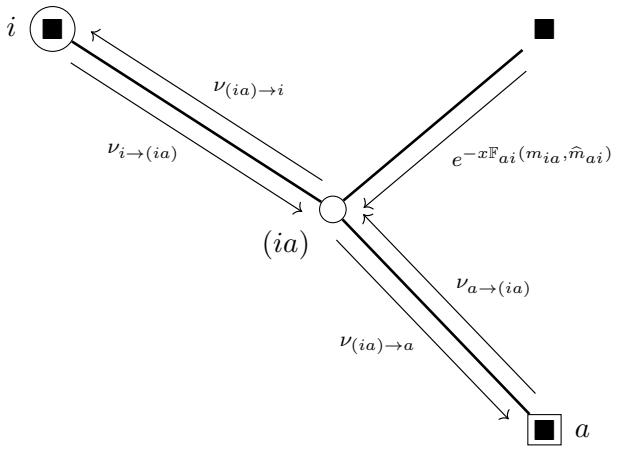


图 19.3: 辅助图模型中的消息。

仍用 $i \in V, a \in F, (ia) \in E$ 表示原图节点、边，也表示辅助图中的对应节点。辅助模型的 BP 消息分为：

1. 变量节点 (ia) 发出的 $\nu_{(ia)\to a}(m_{ia}, \widehat{m}_{ai})$ 和 $\nu_{(ia)\to i}(m_{ia}, \widehat{m}_{ai})$；
2. 函数节点 a 向各邻接节点发出的 $\widehat{\nu}_{a\to(ai)}(m_{ia}, \widehat{m}_{ai})$；
3. 函数节点 i 发出的 $\widehat{\nu}_{i\to(ai)}(m_{ia}, \widehat{m}_{ai})$；
4. 与 (ia) 相连的度 1 函数节点发出 $e^{-xF_{ia}(m_{ia},\widehat{m}_{ai})}$。

变量节点的 BP 方程为

$$\begin{aligned}
\nu_{(ia)\to a}(m_{ia}, \widehat{m}_{ai}) &\cong \widehat{\nu}_{i\to(ia)}(m_{ia}, \widehat{m}_{ai}) e^{-xF_{ia}(m_{ia},\widehat{m}_{ai})}, \\
\nu_{(ia)\to i}(m_{ia}, \widehat{m}_{ai}) &\cong \widehat{\nu}_{a\to(ia)}(m_{ia}, \widehat{m}_{ai}) e^{-xF_{ia}(m_{ia},\widehat{m}_{ai})}. \qquad (19.18)\\
Q_{ia}(m_{ia}, \widehat{m}_{ai}) &\equiv \nu_{(ia)\to a}(m_{ia}, \widehat{m}_{ai}), \\
\widehat{Q}_{ai}(m_{ia}, \widehat{m}_{ai}) &\equiv \nu_{(ia)\to i}(m_{ia}, \widehat{m}_{ai}). \qquad (19.19)
\end{aligned}$$

这样消去函数到变量消息后，原变量节点 i 对应的辅助 BP 方程为

$$Q_{ia}(m_{ia},\widehat{m}_{ai}) \cong \sum_{\{m_{ib},\widehat{m}_{bi}\}_{b\in\partial i\setminus a}} \left[\prod_{c\in\partial i} \mathbb{I}(m_{ic}=f_i(\{\widehat{m}_{di}\}_{d\in\partial i\setminus c}))\right] \times e^{x[F_i(\{\widehat{m}_{bi}\}_{b\in\partial i})-F_{ai}(m_{ia},\widehat{m}_{ai})]} \prod_{b\in\partial i\setminus a} \widehat{Q}_{bi}(m_{ib},\widehat{m}_{bi}), \tag{19.20}$$

$$\widehat{Q}_{ai}(m_{ia},\widehat{m}_{ai}) \cong \sum_{\{m_{ja},\widehat{m}_{aj}\}_{j\in\partial a\setminus i}} \left[\prod_{j\in\partial a} \mathbb{I}(\widehat{m}_{aj}=\widehat{f}_a(\{m_{ka}\}_{k\in\partial a\setminus j}))\right] \tag{19.21}$$

$$\times e^{x[F_a(\{m_{ja}\}_{j\in\partial a})-F_{ai}(m_{ia},\widehat{m}_{ai})]} \prod_{j\in\partial a\setminus i} Q_{ja}(m_{ja},\widehat{m}_{aj}). \tag{19.22}$$

译注： 源式中 F_{ai} 与此前 F_{ia} 互换；仍照录。

引理 19.3. 设 $\sum_{x_i} m_{ia}(x_i)\widehat{m}_{ai}(x_i)>0$。若 $m_{ia}=f_i(\{\widehat{m}_{di}\}_{d\in\partial i\setminus a})$（特别地，若式 (19.20) 的示性函数均为 *1*），则 F_i-F_{ai} 只依赖 $\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a}$，且

$$e^{F_i-F_{ia}} = z_{ia}(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a}) \equiv \sum_{x_i}\prod_{b\in\partial i\setminus a}\widehat{m}_{bi}(x_i). \tag{19.23}$$

$$e^{F_a-F_{ia}} = \widehat{z}_{ai}(\{m_{ja}\}_{j\in\partial a\setminus i}) \equiv \sum_{x_{\partial a}}\psi_a(x_{\partial a})\prod_{j\in\partial a\setminus i} m_{ja}(x_j). \tag{19.24}$$

第二式在 $\widehat{m}_{ai}=\widehat{f}_a(\{m_{ka}\}_{k\in\partial a\setminus i})$ 时成立，特别适用于式 (19.22) 示性函数均为 *1* 的情形。

证明. 由定义，

$$e^{F_i-F_{ia}} = \frac{\sum_{x_i}\prod_{b\in\partial i}\widehat{m}_{bi}(x_i)}{\sum_{x_i} m_{ia}(x_i)\widehat{m}_{ai}(x_i)}. \tag{19.25}$$

$$\sum_{x_i} m_{ia}(x_i)\widehat{m}_{ai}(x_i) = \frac{\sum_{x_i}\prod_{b\in\partial i}\widehat{m}_{bi}(x_i)}{\sum_{x_i}\prod_{b\in\partial i\setminus a}\widehat{m}_{ai}(x_i)}. \tag{19.26}$$

第二行由代入 $m_{ia}=f_i(\{\widehat{m}_{ci}\}_{c\in\partial i\setminus a})$ 并保留归一化常数得到，故推出式 (19.23)。式 (19.24) 完全类似，留作练习。 □

译注： 源式 (19.26) 分母乘积的带帽消息写为 $\widehat{m}_{ai}$，与乘积指标 b 不一致；照录，应核对是否为 $\widehat{m}_{bi}$。

$z_{ia},\widehat{z}_{ai}$ 正是原 BP 更新中 $\cong$ 略去的归一化常数。由此可寻找 Q_{ia} 只依赖 m_{ia}、$\widehat{Q}_{ai}$ 只依赖 $\widehat{m}_{ai}$ 的解。下面仅考虑此类，略滥用记号写为

$$Q_{ia}(m_{ia},\widehat{m}_{ai}) = Q_{ia}(m_{ia}), \qquad \widehat{Q}_{ia}(m_{ia},\widehat{m}_{ai}) = \widehat{Q}_{ai}(\widehat{m}_{ai}). \tag{19.27}$$

辅助 BP 方程化为

$$Q_{ia}(m_{ia}) \cong \sum_{\{\widehat{m}_{bi}\}} \mathbb{I}(m_{ia}=g_i(\{\widehat{m}_{bi}\}))\,[z_{ia}(\{\widehat{m}_{bi}\})]^x \prod_{b\in\partial i\setminus a}\widehat{Q}_{bi}(\widehat{m}_{bi}), \tag{19.28}$$

$$\widehat{Q}_{ai}(\widehat{m}_{ai}) \cong \sum_{\{m_{ja}\}} \mathbb{I}(\widehat{m}_{ai}=f_a(\{m_{ja}\}))\,[\widehat{z}_{ai}(\{m_{ja}\})]^x \prod_{j\in\partial a\setminus i} Q_{ja}(m_{ja}). \tag{19.29}$$

其中集合记号分别简写 $b \in \partial i \setminus a$、$j \in \partial a \setminus i$ 的输入；归一化因子见式 (19.23)、(19.24)。**译注：**源式 (19.27) 左侧带帽 Q 指标为 ia；式 (19.28)、(19.29) 又写 g_i, f_a，与前面 $f_i, \widehat{f}_a$ 的记号不同。这里均保留，不默改。

这就是 1RSB 腔方程。像普通 BP 一样，也可将其视为消息传递算法的更新规则，下节继续。也常记作 $Q_{i\to a}$、$\widehat{Q}_{a\to i}$，强调消息属于有向边。推导假设 $\sum_{x_i} m_{ia}(x_i)\widehat{m}_{ai}(x_i) > 0$；若原相容函数有正下界，此条件成立。在此条件下得到：

命题 19.4. *1RSB 腔方程的解 $Q, \widehat{Q}$ 对应辅助图模型的 BP 解；反之，若辅助模型有满足式 (19.27) 的 BP 解，则相应消息必为 1RSB 腔方程的解。*

式 (19.27) 暗示某种“因果性”，但本途径不能进一步论证它；1RSB 方程的其他推导支持其有效性。

19.2.3 计算复杂度

现在在 BP 近似内计算辅助图模型的自由熵。作者预期对广泛的局部树状模型，这一程序渐近精确，得到正确的 $\mathcal{F}(x) = \lim_N N^{-1}\log \Xi(x)$。设 $Q, \widehat{Q}$ 为 1RSB 方程的解或准解，使用一般 Bethe 式 (14.27)，并用习题 14.6 的简式计入度 1 因子，各项为

$$F_a^{\mathrm{RSB}} = \log\left\{\sum_{\{m_{ia}\}} e^{xF_a(\{m_{ia}\})}\prod_{i\in\partial a} Q_{ia}(m_{ia})\right\}, \tag{19.30}$$

$$F_i^{\mathrm{RSB}} = \log\left\{\sum_{\{\widehat{m}_{ai}\}} e^{xF_i(\{\widehat{m}_{ai}\})}\prod_{a\in\partial i} \widehat{Q}_{ai}(\widehat{m}_{ai})\right\}, \tag{19.31}$$

$$F_{ia}^{\mathrm{RSB}} = \log\left\{\sum_{m_{ia},\widehat{m}_{ai}} e^{xF_{ia}(m_{ia},\widehat{m}_{ai})} Q_{ia}(m_{ia})\widehat{Q}_{ai}(\widehat{m}_{ai})\right\}. \tag{19.32}$$

前两行的输入集合分别遍历 $i \in \partial a$、$a \in \partial i$。辅助图两条边 $a-(ai)$、$i-(ai)$ 的贡献各为 $-F_{ia}^{\mathrm{RSB}}$，于是

$$F^{\mathrm{RSB}}(\{Q, \widehat{Q}\}) = \sum_{a\in F} F_a^{\mathrm{RSB}} + \sum_{i\in V} F_i^{\mathrm{RSB}} - \sum_{(ia)\in E} F_{ia}^{\mathrm{RSB}}. \tag{19.33}$$

19.2.4 小结

1RSB 腔方程是辅助图模型的 BP 方程，联系 $2|E|$ 个消息 $\{Q_{ia}(m_{ia}), \widehat{Q}_{ai}(\widehat{m}_{ai})\}$。每个消息是普通 BP 消息的分布，而普通 BP 消息本身又是 $\mathcal{X}$ 上概率分布。给定其解或近似解，可估计

$$\log \Xi(x) = F^{\mathrm{RSB}}(\{Q, \widehat{Q}\}) + \mathrm{err}_N\,. \tag{19.34}$$

对广泛的局部树状模型，作者预期辅助模型的 BP 近似渐近精确，即 $\mathrm{err}_N = o(N)$。此时 $\mathcal{F}(x) = f^{\mathrm{RSB}}(x) \equiv \lim_N F^{\mathrm{RSB}}/N$，再以 Legendre 变换计算 Σ。

19.2.5 随机图模型与密度演化

考虑第 14 章定义的随机图模型。图服从 $G_N(K,\alpha)$ 或 $D_N(\Lambda,P)$；给定度 k，从由标签 $\widehat{J}$ 标记的有限列表 $\psi^{(k)}(x_1,\dots,x_k;\widehat{J})$，依 $P_{\widehat{J}}^{(k)}$ 独立抽取各因子。每个变量另接单变量因子 $\psi(x;J)$，标签依 P_J 独立抽取。**译注：**独立抽取因子标签应条件于图及度数，不将随机元数本身视作独立于图；与前章相同。

模型随机，极端 Bethe 态分解、权重和消息集也随机。须牢记“两层”随机性：给定边后，随机抽取态 n 使普通消息 $\nu_{i\to a}^{n}$ 随机，其分布是 Q_{ia}；图模型本身再随机时，Q_{ia} 才成为随机变量。

可用密度演化研究 $Q_{ia},\widehat{Q}_{ai}$ 的分布。设初始消息独立同分布，分别与随机分布 $Q^{(0)},\widehat{Q}^{(0)}$ 同分布。平行更新 t 次后，均匀随机边上消息在 $N\to\infty$ 时依分布趋于 $Q^{(t)},\widehat{Q}^{(t)}$[4]，它们满足

$$Q^{(t+1)}(m)\overset{d}{=}\sum_{\{\widehat{m}_b\}}\mathbb{I}(m=f(\{\widehat{m}_b\};J))\,z(\{\widehat{m}_b\};J)^x\prod_{b=1}^{l-1}\widehat{Q}_b^{(t)}(\widehat{m}_b),\tag{19.35}$$

$$\widehat{Q}^{(t)}(\widehat{m})\overset{d}{=}\sum_{\{m_j\}}\mathbb{I}[\widehat{m}=\widehat{f}(\{m_j\};\widehat{J})]\,\widehat{z}(\{m_j\};\widehat{J})^x\prod_{j=1}^{k-1}Q_j^{(t)}(m_j).\tag{19.36}$$

k,l 分别依边视角分布 ρ_k,λ_l 抽取；原文紧随其后的文字称 $\{\widehat{Q}_b^{(t)}\}$ 是 $k-1$ 个独立副本，$\{Q_j^{(t)}\}$ 是 $l-1$ 个独立副本。归一化因子为

$$\begin{aligned}z(\{\widehat{m}_b\};J)&=\sum_x\psi(x;J)\prod_{b=1}^{l-1}\widehat{m}_b(x),\\ \widehat{z}(\{m_j\};\widehat{J})&=\sum_{x_1,\dots,x_k}\psi^{(k)}(x_1,\dots,x_k;\widehat{J})\prod_{j=1}^{k-1}m_j(x_j).\end{aligned}\tag{19.37}$$

译注：源文字的副本数 $k-1,l-1$ 与前两式的实际乘积范围相反，均保留。有限深邻域论证先固定 t 再取 $N\to\infty$；下段交换极限的期望另属假设。

1RSB 腔方法假定实际 $Q_{i\to a}$ 分布等于上述密度演化某不动点。如 RS 情形，人们希望足够大实例上算法收敛到此分布，即交换 t,N 极限没有问题；可作数值检验。

随机图模型的 1RSB 自由熵密度趋于有限 $f^{\mathrm{RSB}}(x)$。若同节点入消息独立同分布，对各局域项取期望，得到

$$f^{\mathrm{RSB}}=f_v^{\mathrm{RSB}}+n_f f_f^{\mathrm{RSB}}-n_e f_e^{\mathrm{RSB}},\tag{19.38}$$

D_N 中 $n_f=\Lambda'(1)/P'(1),n_e=\Lambda'(1)$；$G_N$ 中分别为 $\alpha,K\alpha$。三项为

$$\begin{aligned}f_v^{\mathrm{RSB}}&=\mathbb{E}_{l,J,\{\widehat{Q}\}}\log\left\{\sum_{\{\widehat{m}_b\}}\prod_{b=1}^{l}\widehat{Q}_b(\widehat{m}_b)\left[\sum_{x\in\mathcal{X}}\psi(x;J)\prod_{b=1}^{l}\widehat{m}_b(x)\right]^x\right\},\\ f_f^{\mathrm{RSB}}&=\mathbb{E}_{k,\widehat{J},\{Q\}}\log\left\{\sum_{\{m_j\}}\prod_{j=1}^{k}Q_j(m_j)\left[\sum_{x_1,\dots,x_k\in\mathcal{X}}\psi^{(k)}(x_1,\dots,x_k;\widehat{J})\prod_{j=1}^{k}m_j(x_j)\right]^x\right\},\\ f_e^{\mathrm{RSB}}&=\mathbb{E}_{Q,\widehat{Q}}\log\left\{\sum_{m,\widehat{m}}\widehat{Q}(\widehat{m})Q(m)\left[\sum_{x\in\mathcal{X}}\widehat{m}(x)m(x)\right]^x\right\}.\end{aligned}\tag{19.39}$$

[4]不讨论测度论细节；消息 $Q^{(t)}$ 所在空间采用弱拓扑。

19.2.6 数值实现

寻找分布递推不动点极为困难。可推广 RS 中的种群动力学，但有两点变化：

1. 待求对象本身是消息的分布，所以需要两层种群。用 $\mathcal{N}\mathcal{M}$ 个消息 $\{m_r^s\}$，对每个 $r \in \{1,\dots,\mathcal{N}\}$，内层 $s \in \{1,\dots,\mathcal{M}\}$ 表示分布 Q_r，理想情况是其独立同分布样本；外层 $\{Q_r\}$ 再表示随机 Q 的分布。带帽消息也用同样大小的种群。

2. RS 中没有 $z^x, \widehat{z}^x$ 这样的重加权因子。可先产生带权中间种群，再按权重比例重新采样。

下面抄列算法，$\mathcal{N},\mathcal{M}$ 是两层种群大小，T 是迭代次数：

1. 初始化 $\{m_r^s\}$。

2. 对 $t = 1,\dots,T$：

   (a) 对每个 $r = 1,\dots,\mathcal{N}$：依 ρ 抽取 k，在 $\{1,\dots,\mathcal{N}\}$ 均匀抽 $i(1),\dots,i(k-1)$，依 $P_{\widehat{J}}^{(k)}$ 抽 $\widehat{J}$。

   (b) 对 $s = 1,\dots,\mathcal{M}$，均匀抽 $s(1),\dots,s(k-1) \in \{1,\dots,\mathcal{M}\}$，计算

$$\widehat{m}^s_{\text{temp}} = \widehat{f}(m^{s(1)}_{i(1)},\dots,m^{s(k-1)}_{i(k-1)};\widehat{J}),$$
$$W^s = \widehat{z}(m^{s(1)}_{i(1)},\dots,m^{s(k-1)}_{i(k-1)};\widehat{J})^x.$$

   产生 $\{\widehat{m}_r^s\}_{s\in[\mathcal{M}]} = \text{Reweight}(\{\widehat{m}^s_{\text{temp}}, W^s\}_{s\in[\mathcal{M}]})$，完成各 r。

   (c) 再对 $r = 1,\dots,\mathcal{N}$，依 λ 抽 l，均匀抽 $i(1),\dots,i(l-1)$，依 P 抽 J。

   (d) 对 $s = 1,\dots,\mathcal{M}$ 均匀抽 $s(1),\dots,s(l-1)$，计算

$$m^s_{\text{temp}} = f(\widehat{m}^{s(1)}_{i(1)},\dots,\widehat{m}^{s(k-1)}_{i(l-1)};J),$$
$$W^s = z(\widehat{m}^{s(1)}_{i(1)},\dots,\widehat{m}^{s(l-1)}_{i(l-1)};J)^x.$$

   产生 $\{m_r^s\}_{s\in[\mathcal{M}]} = \text{Reweight}(\{m^s_{\text{temp}}, W^s\}_{s\in[\mathcal{M}]})$。

3. 返回 $\{\widehat{m}_r^s\}$ 与 $\{m_r^s\}$。

译注：源伪代码第二轮 f 的末个内层指标写为 $s(k-1)$，与此轮 $l-1$ 个输入不符，照录。原伪代码末尾循环结束标记也不完全对齐；此处用嵌套列表表达已有的两重更新及时间循环，不据此声称源代码可直接运行。

重加权过程为：

1. 对 $s = 1,\dots,\mathcal{M}$，令 $p_s = W^s / \sum_{s'} W^{s'}$。

2. 对每个新样本 s，依 p 抽 $i \in \{1,\dots,\mathcal{M}\}$，置 $m^s_{\text{new}} = m^i_{\text{temp}}$。

3. 返回 $\{m^s_{\text{new}}\}$。

译注：重加权须有有限、正的总权重；零总权重时原伪代码没有指定处理。

在大 $\mathcal{N},\mathcal{M}$ 极限，生成种群应趋于 $Q^{(T)},\widehat{Q}^{(T)}$ 的独立样本；增大 T 应准确表示不动点，但 RS 时的收敛保留条件仍适用。也可用种群估计自由熵。例如给定 $\widehat{m}_r^s(\cdot)$，变量贡献估计为

$$\widehat{f}_v^{\mathrm{RSB}}=\mathbb{E}_{l,J}\frac{1}{\mathcal{N}^l}\sum_{r(1),\dots,r(l)=1}^{\mathcal{N}}\log\left\{\frac{1}{\mathcal{M}^l}\sum_{s(1),\dots,s(l)=1}^{\mathcal{M}}\left[\sum_{x\in\mathcal{X}}\psi(x;J)\prod_{b=1}^{l}\widehat{m}_{r(b)}^{s(b)}(x)\right]^x\right\}.$$

因子与边项类似。可随机抽取部分外层、内层多元组，加快近似求和；也可像 RS 时那样跨迭代、即跨 T 平均，以较小成本降低统计误差。

19.3 第一个应用：XORSAT

第 18 章已初步介绍 XORSAT 的 1RSB 途径，现在说明它如何成为一般形式的特例，在熟悉问题上建立更复杂应用所需直觉。考虑 $x\in\{0,1\}^N$ 上

$$\mu(x)=\frac{1}{Z}\prod_{a=1}^{M}\mathbb{I}(x_{i_1(a)}\oplus\cdots\oplus x_{i_k(a)}=b_a). \tag{19.40}$$

$\partial a=\{i_1(a),\dots,i_K(a)\}\subseteq\{1,\dots,N\}$，$b_a\in\{0,1\}$；随机公式将每个指标集和右端均匀抽取。

19.3.1 BP 方程

$$m_{ia}(x_i)=\frac{1}{z_{ia}}\prod_{b\in\partial i\setminus a}\widehat{m}_{bi}(x_i), \tag{19.41}$$

$$\widehat{m}_{ai}(x_i)=\frac{1}{\widehat{z}_{ai}}\sum_{x_{\partial a\setminus i}}\mathbb{I}(x_{i_1(a)}\oplus\cdots\oplus x_{i_K(a)}=b_a)\prod_{j\in\partial a\setminus i}m_{ja}(x_j). \tag{19.42}$$

仍只考虑三类消息：集中于 0 简记 0，集中于 1 简记 1，均匀分布简记 $*$。变量更新的输入中三类消息数分别为 n_0,n_1,n_*，则

$$m_{ia}=\begin{cases}0, & n_0>0,n_1=0,\\ 1, & n_0=0,n_1>0,\\ , & n_0=n_1=0,\\ ?, & n_0>0,n_1>0,\end{cases}\qquad z_{ia}=\begin{cases}2^{-n_*}, & n_0>0,n_1=0,\\ 2^{-n_*}, & n_0=0,n_1>0,\\ 2^{1-n_*}, & n_0=n_1=0,\\ 0, & n_0>0,n_1>0.\end{cases} \tag{19.43}$$

最后一类输入矛盾，消息未定义，但归一化因子为零，源文称它在 1RSB 内不造成问题。因子更新的输入数记 $\widehat{n}_0,\widehat{n}_1,\widehat{n}_*$，原式写为

$$\widehat{m}_{ai}=\begin{cases}0, & n_*=0,\ n_1\ \text{与}b_a\ \text{同奇偶},\\ 1, & n_*=0,\ n_1\ \text{与}b_a\ \text{奇偶不同},\\ , & n_*>0.\end{cases} \tag{19.44}$$

三类均有 $\widehat{z}_{ai}=1$。**译注：**源式 (19.44) 中计数未带前句定义的帽，照录。前段“零权重不造成问题”在用 z^x 时仍须规定 $x=0$ 的 0^0、负 x 等边界，不能无条件代入。

前章已说明典型实例在 $\alpha<\alpha_d$ 时，只有每边均为 $*$ 的唯一 BP 解。

习题 19.2. 计算该解的 *Bethe* 自由熵，证明自由熵密度为 $f^{\mathrm{RS}} = (1-\alpha)\log 2$。

19.3.2 1RSB 腔方程

现在假设 BP 方程有许多解，以 1RSB 研究其统计。消息 $Q, \widehat{Q}$ 是 $\{0,1,*\}$ 上分布。由变量方程得到

$$Q_{ia}(0) = \frac{1}{Z_{ia}} \left\{ \prod_{b\in\partial i\backslash a} [\widehat{Q}_{bi}(0) + 2^{-x}\widehat{Q}_{bi}(*)] - \prod_{b\in\partial i\backslash a} [2^{-x}\widehat{Q}_{bi}(*)] \right\}, \tag{19.45}$$

$$Q_{ia}(1) = \frac{1}{Z_{ia}} \left\{ \prod_{b\in\partial i\backslash a} [\widehat{Q}_{bi}(1) + 2^{-x}\widehat{Q}_{bi}(*)] - \prod_{b\in\partial i\backslash a} [2^{-x}\widehat{Q}_{bi}(*)] \right\}, \tag{19.46}$$

$$Q_{ia}(*) = \frac{2^x}{Z_{ia}} \prod_{b\in\partial i\backslash a} [2^{-x}\widehat{Q}_{bi}(*)]. \tag{19.47}$$

例如第一式要求所有输入属于 $\{*,0\}$，再扣除全 $*$ 情形；重权重 $z_{ia}^{x} = 2^{-xn_*}$ 可分解到各 $*$ 输入。因子方程为

$$\widehat{Q}_{ai}(0) = \frac{1}{2} \left\{ \prod_{j\in\partial a\backslash i} [Q_{ja}(0) + Q_{ja}(1)] + s(b_a) \prod_{j\in\partial a\backslash i} [Q_{ja}(0) - Q_{ja}(1)] \right\}, \tag{19.48}$$

$$\widehat{Q}_{ai}(1) = \frac{1}{2} \left\{ \prod_{j\in\partial a\backslash i} [Q_{ja}(0) + Q_{ja}(1)] - s(b_a) \prod_{j\in\partial a\backslash i} [Q_{ja}(0) - Q_{ja}(1)] \right\}, \tag{19.49}$$

$$\widehat{Q}_{ai}(*) = 1 - \prod_{j\in\partial a\backslash i} [Q_{ja}(0) + Q_{ja}(1)], \qquad s(b_a) = (-1)^{b_a}. \tag{19.50}$$

取 $x = 0$ 就回到前章齐次问题的方程（$b_a = 0$）。如前章，寻找只有两类消息的解：$Q(0) = Q(1) = 1/2$ 或 $Q(*) = 1$，带帽同理。此假设与方程相容，且 x 依赖消失，恢复前章分析。

令 Q_* 为随机边携带 $Q_{ia}(0) = Q_{ia}(1) = 1/2$ 的概率，密度演化不动点满足

$$Q_* = 1 - e^{-k\alpha Q_*^{k-1}}, \tag{19.51}$$

$$\widehat{Q}_* = Q_*^{k-1}. \tag{19.52}$$

$\alpha < \alpha_d(K)$ 时只有 $Q_* = 0$，即以高概率 $Q_{ia}(*) = 1$，再次说明普通 BP 只有全 $*$ 解。超过阈值后出现一对正解，表示大量 BP 不动点、从而 Bethe 测度的出现。密度演化稳定性提示选最大解。$\widehat{Q}_*$ 是随机边上带帽消息满足 $\widehat{Q}_{ai}(0) = \widehat{Q}_{ai}(1) = 1/2$ 的概率。**译注：** 源本节在同一固定子句度中混用大写 K 与小写 k，保留各式原字形。

19.3.3 复杂度

计算辅助模型 Bethe 自由熵，再作 Legendre 变换。先看因子贡献，其权重为

$$e^{F_a(\{m_{ia}\})} = \sum_{x_{\partial a}} \mathbb{I}(x_{i_1(a)} \oplus \cdots \oplus x_{i_K(a)} = b_a) \prod_{i\in\partial a} m_{ia}(x_i). \tag{19.53}$$

$$e^{F_a} = \begin{cases} 1/2, & \widehat{n}_* > 0, \\ 1, & \widehat{n}_* = 0,\ \widehat{n}_1 \text{ 与} b_a \text{ 同奇偶}, \\ 0, & \widehat{n}_* = 0,\ \widehat{n}_1 \text{ 与} b_a \text{ 奇偶不同}. \end{cases} \tag{19.54}$$

这里 $\widehat{n}_0, \widehat{n}_1, \widehat{n}_*$ 计数全部 $i \in \partial a$ 的输入类型。假定各输入独立依 Q_{ia} 分布，且 $Q_{ia}(0) = Q_{ia}(1)$，则

$$F_a^{\mathrm{RSB}} = \log\left\{ \frac{1}{2}\prod_{i\in\partial a}[1 - Q_{ia}(*)] + \frac{1}{2^x}\left[1 - \prod_{i\in\partial a}[1 - Q_{ia}(*)]\right]\right\}. \tag{19.55}$$

第一项对应无 $*$，其中奇偶与 b_a 匹配的概率为 $1/2$；第二项对应至少一个 $*$。所选解中 $Q_{ia}(*)$ 只为 0 或 1，所以两项仅一项非零：全为 0 时 $F_a^{\mathrm{RSB}} = -\log 2$；至少一个为 1 时 $F_a^{\mathrm{RSB}} = -x\log 2$。对随机实例，这两类的概率为 Q_*^k、$1 - Q_*^k$，故

$$\mathbb{E}F_a^{\mathrm{RSB}} = -[Q_*^k + x(1 - Q_*^k)]\log 2 + o_N(1), \tag{19.56}$$

$$\frac{1}{N}\sum_{a\in F} F_a^{\mathrm{RSB}} = -\alpha[Q_*^k + x(1 - Q_*^k)]\log 2 + o_N(1). \tag{19.57}$$

第二行还假设 1RSB 消息短程关联，从而和集中于期望。

其余两项类似，略述并请读者补细节。变量贡献中，设 n_* 个邻接因子有 $\widehat{Q}_{ai}(*) = 1$，n_0 个有 $\widehat{Q}_{ai}(0) = \widehat{Q}_{ai}(1) = 1/2$。若 $n_0 \geq 1$，$F_i^{\mathrm{RSB}} = -(n_* x + n_0 - 1)\log 2$；否则为 $-(n_* - 1)x\log 2$。n_0, n_* 为 Poisson 变量，均值分别为 $k\alpha\widehat{Q}_*$、$k\alpha(1 - \widehat{Q}_*)$；平均得到

$$\frac{1}{N}\sum_i F_i^{\mathrm{RSB}} = -\left\{[k\alpha\widehat{Q}_* - 1 + e^{-k\alpha\widehat{Q}_*}] + [k\alpha(1 - \widehat{Q}_*) - e^{-k\alpha\widehat{Q}_*}]x\right\}\log 2 + o_N(1). \tag{19.58}$$

边贡献中，若两个调查均在 0、1 上均匀，则 $e^{F_{ia}}$ 以各半概率为 1 或 0，得到 $F_{ia}^{\mathrm{RSB}} = -\log 2$；若至少一个调查集中于 $*$，则 $e^{F_{ia}} = 1/2$、$F_{ia}^{\mathrm{RSB}} = -x\log 2$。合计以高概率

$$\frac{1}{N}\sum_{(ia)\in E} F_{(ia)}^{\mathrm{RSB}} = -k\alpha[Q_*\widehat{Q}_* + (1 - Q_*\widehat{Q}_*)x]\log 2 + o_N(1). \tag{19.59}$$

收集各项，$F^{\mathrm{RSB}}(x) = Nf^{\mathrm{RSB}}(x) + o(N)$，$f^{\mathrm{RSB}}(x) = [\Sigma_{\mathrm{tot}} + x\varphi_{\mathrm{typ}}]\log 2$，其中

$$\Sigma_{\mathrm{tot}} = k\alpha Q_*\widehat{Q}_* - k\alpha\widehat{Q}_* - \alpha Q_*^k + 1 - e^{-k\alpha\widehat{Q}_*}, \tag{19.60}$$

$$\varphi_{\mathrm{typ}} = -k\alpha Q_*\widehat{Q}_* + k\alpha\widehat{Q}_* + \alpha Q_*^k - \alpha + e^{-k\alpha\widehat{Q}_*}. \tag{19.61}$$

其中取式 (19.51) 的最大解，并满足式 (19.52)。

习题 19.3. 证明 $\Sigma_{\mathrm{tot}}(Q_*, \widehat{Q}_*)$ 的驻点恰与上述两不动点方程的解相同。

对 x 线性的依赖使 Legendre 变换直接给出

$$\Sigma(\varphi)=\begin{cases}\Sigma_{\rm tot}, & \varphi=\varphi_{\rm typ},\\ -\infty, & \text{其他情形.}\end{cases} \tag{19.62}$$

即有 $2^{N\Sigma_{\rm tot}}$ 个 Bethe 测度，熵均为 $N\varphi_{\rm typ}\log 2$。又有 $\Sigma_{\rm tot}+\varphi_{\rm typ}=1-\alpha$，总熵为 $(1-\alpha)\log 2$；也可写为

$$\frac{1}{2^{N(1-\alpha)}}=\frac{1}{2^{N\Sigma_{\rm tot}}}\frac{1}{2^{N\varphi_{\rm typ}}}. \tag{19.63}$$

这正是极端 Bethe 测度分解：若 x 为解，$\mu(x)=2^{-N(1-\alpha)}$、$w_n\simeq 2^{-N\Sigma_{\rm tot}}$；假设各态支撑不交，包含 x 的态有 $\mu_n(x)\simeq 2^{-N\varphi_{\rm typ}}$。**译注：** 一般形式的 Σ,φ 按自然对数计量，本节 $\Sigma_{\rm tot},\varphi_{\rm typ}$ 却按比特计量，故有显式 $\log 2$。源式 (19.62) 未另写单位换算；此处保留，不把两套参数直接等同。

这里复杂度与前章团簇数的对数结果相同，为假设提供独立检验，特别说明团簇数与 Bethe 测度数在领先阶相同。SAT–UNSAT 转变在 $\Sigma_{\rm tot}$ 消失时出现，此时每团簇仍含 $2^{N(1-\alpha_s)}$ 个构型。

习题 19.4. 对因子图服从 $D_N(\Lambda,P)$ 的布尔线性系统重复分析：P_k 是含 k 变量的方程比例，Λ_ℓ 是出现在 ℓ 方程中的变量比例。

(a) 证明

$$\widehat{Q}_*=\rho(Q_*),\qquad\qquad Q_*=1-\lambda(1-\widehat{Q}_*). \tag{19.64}$$

(b) 证明复杂度为

$$\Sigma_{\rm tot}=1-\frac{\Lambda'(1)}{P'(1)}P(Q_*)-\Lambda(1-\widehat{Q}_*)-\Lambda'(1)(1-Q_*)\widehat{Q}_*, \tag{19.65}$$

团簇内部熵为 $\varphi_{\rm typ}=1-\Lambda'(1)/P'(1)-\Sigma_{\rm tot}$。

(c) 若全部变量度严格大于 *1*、故 $\lambda(0)=0$，说明有关解为 $Q_*=\widehat{Q}_*=1$，$\Sigma_{\rm tot}=1-\Lambda'(1)/P'(1)$、$\varphi_{\rm typ}=0$。结合前章核结构解释。

19.4 特殊取值 $x=1$

回到一般形式。$x=1$ 时辅助模型中各 Bethe 测度的权重，与原测度分解中的权重相同，因此有若干特别性质。

19.4.1 回到 BP

将重加权因子显式代入 $x=1$ 的腔方程，得到

$$Q_{ia}(m_{ia})\cong\sum_{x_i}\sum_{\{\widehat{m}_{bi}\}}\mathbb{I}(m_{ia}=g_i(\{\widehat{m}_{bi}\}))\prod_{b\in\partial i\backslash a}\widehat{Q}_{bi}(\widehat{m}_{bi})\widehat{m}_{bi}(x_i), \tag{19.66}$$

$$\widehat{Q}_{ai}(\widehat{m}_{ai})\cong\sum_{x_{\partial a}}\psi_a(x_{\partial a})\sum_{\{m_{ja}\}}\mathbb{I}(\widehat{m}_{ai}=f_a(\{m_{ja}\}))\prod_{j\in\partial a\backslash i}Q_{ja}(m_{ja})m_{ja}(x_j). \tag{19.67}$$

定义 1RSB 消息的平均

$$\nu^{\mathrm{av}}_{i\to a}(x_i)=\sum_{m_{ia}}Q_{ia}(m_{ia})m_{ia}(x_i),\qquad \widehat{\nu}^{\mathrm{av}}_{a\to i}(x_i)=\sum_{\widehat{m}_{ai}}\widehat{Q}_{ai}(\widehat{m}_{ai})\widehat{m}_{ai}(x_i).$$

即按 w_n 抽取极端态后，对该态的普通 BP 消息取期望。利用原 BP 的显式形式，可得

$$\nu^{\mathrm{av}}_{i\to a}(x_i)\cong\prod_{b\in\partial i\setminus a}\widehat{\nu}^{\mathrm{av}}_{b\to i}(x_i),\tag{19.68}$$

$$\widehat{\nu}^{\mathrm{av}}_{a\to i}(x_i)\cong\sum_{\{x_j\}_{j\in\partial a\setminus i}}\psi_a(x_{\partial a})\prod_{j\in\partial a\setminus i}\nu^{\mathrm{av}}_{j\to a}(x_j).\tag{19.69}$$

这正是普通 BP 方程。它提示，即使 μ 分解成指数多个极端 Bethe 测度，它本身仍是一个非极端 Bethe 测度；特别地，有相应的 BP 准解可计算其边缘。

既然用“正确”权重后又回到简单 BP，何必 1RSB？至少有两个原因：

1. 1RSB 提供极端态分解、长程关联、复杂度等更精细的图像，本身就有价值。
2. 静态 s1RSB 相中，$x=1$ 对应“非物理”的 1RSB 解；渐近正确的边缘反而须取某个 $x=x_*\in[0,1)$。此时必须用完整形式，见第 19.6 节。

19.4.2 更简单的递推

控制一般分布递推无论数值还是解析都困难。$x=1$ 时可大幅简化并作更精确数值研究。仍考虑随机图模型，另假定“局域均匀性”：原测度本身对消息 $\nu^{\mathrm{av}}_{i\to a}(x_i)=\widehat{\nu}^{\mathrm{av}}_{a\to i}(x_i)=1/q$ 是 Bethe 测度，$q=|\mathcal{X}|$。此条件并非必需，但大幅简化推导，一般情形见文献。

此时易计算归一化常数，再对图与因子标签平均。平均分布 $Q_{\mathrm{av}},\widehat{Q}_{\mathrm{av}}$ 满足

$$Q^{(t+1)}_{\mathrm{av}}(m)=\mathbb{E}\left\{q^{l-2}\sum_{\{\widehat{m}_b\}}\mathbb{I}(m=f(\{\widehat{m}_b\};J))z(\{\widehat{m}_b\})\prod_{b=1}^{l-1}\widehat{Q}^{(t)}_{\mathrm{av}}(\widehat{m}_b)\right\},\tag{19.70}$$

$$\widehat{Q}^{(t)}_{\mathrm{av}}(\widehat{m})=\mathbb{E}\left\{\frac{q^{k-2}}{\overline{\psi}_k}\sum_{\{m_j\}}\mathbb{I}[\widehat{m}=\widehat{f}(\{m_j\};\widehat{J})]\widehat{z}(\{m_j\};\widehat{J})\prod_{j=1}^{k-1}Q^{(t)}_{\mathrm{av}}(m_j)\right\}.\tag{19.71}$$

期望依随机模型对 $l,k,J,\widehat{J}$ 取；$\overline{\psi}_k=\sum_{x_1,\dots,x_{k-1}}\psi(x_1,\dots,x_{k-1},x;\widehat{J})$ 可证与 x 无关，这也是均匀性的必要条件。平均分布已非随机对象，但重加权仍难处理。对每个字母 $x\in\mathcal{X}$ 定义

$$\widehat{R}^{(t)}_x(m)=qm(x)\widehat{Q}^{(t)}_{\mathrm{av}}(m),\qquad R^{(t)}_x(m)=qm(x)Q^{(t)}_{\mathrm{av}}(m).\tag{19.72}$$

便可消去重加权，得到

$$R^{(t+1)}_x(m)=\mathbb{E}\left\{\sum_{\{\widehat{m}_b\}}\mathbb{I}(m=g(\{\widehat{m}_b\};J))\prod_{b=1}^{l-1}\widehat{R}^{(t)}_x(\widehat{m}_b)\right\},\tag{19.73}$$

$$\widehat{R}^{(t)}_x(\widehat{m})=\mathbb{E}\left\{\sum_{\{x_j\}}\pi(\{x_j\}\mid x;\widehat{J})\sum_{\{m_j\}}\mathbb{I}[\widehat{m}=f(\{m_j\};\widehat{J})]\prod_{j=1}^{k-1}R^{(t)}_{x_j}(m_j)\right\},\tag{19.74}$$

$$\pi(x_1,\dots,x_{k-1}\mid x;\widehat{J})=\frac{\psi(x_1,\dots,x_{k-1},x;\widehat{J})}{\sum_{y_1,\dots,y_{k-1}}\psi(y_1,\dots,y_{k-1},x;\widehat{J})}.\tag{19.75}$$

期望对 $l,J,k,\widehat{J}$ 取。源式中的 $f,g,\widehat{f}$ 记号变化仍照录，式 (19.74) 因子更新处的 f 未带帽。

习题 19.5. 证明上述两个递推。可使用重加权因子的显式关系

$$z(\{\widehat{m}_b\})m(x)=\prod_{b=1}^{l-1}\widehat{m}_b(x), \tag{19.76}$$

$$\widehat{z}(\{m_j\};\widehat{J})\widehat{m}(x)=\sum_{\{x_i\},x}\psi(x_1,\dots,x_{k-1},x;\widehat{J})\prod_{j=1}^{k-1}m_j(x_j). \tag{19.77}$$

译注： 源式 (19.77) 的求和指标包括左端自由变量 x，与固定输出字母的恒等式不一致；源式保留，不静默删去该指标。

操作上，因子更新先抽 $\widehat{J},k$，给定 x 按核 π 抽 $x_1,\dots,x_{k-1}$，再独立按各 $R_{x_j}^{(t)}$ 抽消息，输出便服从 $\widehat{R}_x^{(t)}$。变量更新则抽 J,l，给定 x 后独立按 $\widehat{R}_x^{(t)}$ 抽 $l-1$ 个消息，输出服从 $R_x^{(t+1)}$。第 22 章将说明它与测度下“点到集关联”的计算过程一致。

因此 $x=1$ 时，不再需要“分布的分布”，也不再需要重加权；还有第三个关键简化：

定理 19.5. *1RSB 方程存在非平凡、即不同于 RS 的解，当且仅当以集中于 $m(y)=\mathbb{I}(y=x)$ 的单点分布初始化 $R_x^{(0)}$ 后，式 (19.73)、(19.74) 随 $t\to\infty$ 收敛到非平凡分布。*

这消除了 $x=1$ 时迭代初值的歧义：若有非平凡解，便可从此初值达到。证明见文献。

习题 19.6. 证明辅助模型自由熵 $F^{\mathrm{RSB}}(x)$ 在 $x=1$ 等于 *RS Bethe* 自由熵；其在此处对 x 的导数可用不动点分布 $R_x^{(\infty)},\widehat{R}_x^{(\infty)}$ 表示，因而可从简化方程不动点计算复杂度和内部自由熵。

结论是 $x=1$ 的 1RSB 计算技术上不比 RS 更难；该特殊取值的重要性使这一点有多种应用。

19.5 调查传播

其他具有多个不动点的消息传递算法也可用 1RSB。特别重要的是最小和算法：物理上它试图计算基态构型和能量，因此 RS 及 1RSB 形式也称能量腔方法。将相应 1RSB 算法称为有限 y 的调查传播 SP(y)。

19.5.1 SP(y) 方程

为强调与 BP 形式的联系，沿用消息记号：

$$m_{ja}(x_j)\equiv E_{i\to a}(x_i), \qquad \widehat{m}_{ai}(x_i)\equiv\widehat{E}_{a\to i}(x_i), \tag{19.78}$$

$$m_{ia}=f_i^e(\{\widehat{m}_{bi}\}_{b\in\partial i\backslash a}), \qquad \widehat{m}_{ai}=\widehat{f}_a^e(\{m_{ja}\}_{j\in\partial a\backslash i}), \tag{19.79}$$

$$m_{ia}(x_i)=\sum_{b\in\partial i\backslash a}\widehat{m}_{bi}(x_i)-u_{ia}, \tag{19.80}$$

$$\widehat{m}_{ai}(x_i)=\min_{x_{\partial a\backslash i}}\left[E_a(x_{\partial a})+\sum_{j\in\partial a\backslash i}m_{ja}(x_j)\right]-\widehat{u}_{ai}. \tag{19.81}$$

归一化常数与 x_i 无关，使两类消息的最小分量均为 0。每组消息对应 Bethe 能量

$$F^e(m,\widehat{m})=\sum_a F_a^e(\{m_{ia}\}_{i\in\partial a})+\sum_i F_i^e(\{\widehat{m}_{ai}\}_{a\in\partial i})-\sum_{(ia)} F_{ia}^e(m_{ia},\widehat{m}_{ai}), \tag{19.82}$$

$$\begin{aligned}
F_a^e &= \min_{x_{\partial a}}\left[E_a(x_{\partial a})+\sum_{j\in\partial a} m_{ia}(x_i)\right],\\
F_i^e &= \min_{x_i}\sum_{a\in\partial i}\widehat{m}_{ai}(x_i),\\
F_{ia}^e &= \min_{x_i}[m_{ia}(x_i)+\widehat{m}_{ai}(x_i)].
\end{aligned} \tag{19.83}$$

译注： 源式 (19.78) 左右的 j,i 不同；式 (19.83) 因子项求和指标 j 与被求和消息 $m_{ia}(x_i)$ 不同，均照录。第 14 章的最小和消息记为 J，本节原文改称 E；不将该记号变化隐去。

算法和能量泛函给定后，可重复先前程序。

假设 4。最小和方程有指数多个准解 $\{m^n\}$，Bethe 能量 $F^e(m^n)\simeq N\epsilon$ 的准解数，在领先指数阶为 $e^{N\Sigma^e(\epsilon)}$，Σ^e 称能量复杂度。

为估计它，引入以最小和消息为变量的辅助图模型，强制消息在一定精度内满足更新，每解的权重为 e^{-yF^e}，$y\in\mathbb{R}$：

$$P_y(m,\widehat{m})=\frac{1}{\Xi(y)}\prod_a\Psi_a(\{m_{ja},\widehat{m}_{ja}\}_{j\in\partial a})\prod_i\Psi_i(\{m_{ib},\widehat{m}_{ib}\}_{b\in\partial i})\prod_{(ia)}\Psi_{ia}(m_{ia},\widehat{m}_{ia}), \tag{19.84}$$

$$\Psi_a=\prod_{i\in\partial a}\mathbb{I}[\widehat{m}_{ai}=\widehat{f}_a^e(\{m_{ja}\}_{j\in\partial a\setminus i})]e^{-yF_a^e}, \tag{19.85}$$

$$\Psi_i=\prod_{a\in\partial i}\mathbb{I}[m_{ia}=f_i^e(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a})]e^{-yF_i^e}, \tag{19.86}$$

$$\Psi_{ia}=e^{yF_{ia}^e(m_{ia},\widehat{m}_{ai})}. \tag{19.87}$$

源分布中的带帽指标互换仍按原保留。辅助模型仍局部树状，可希望 BP 给出渐近精确结果。辅助消息 $Q,\widehat{Q}$ 是最小和消息的分布，再加前述因果性假设得到 SP(y)。推导几乎逐字相同，只须谨慎改写归一化引理。

引理 19.6. *设至少某个 x_i 使 $m_{ia}(x_i)+\widehat{m}_{ai}(x_i)<\infty$。若 $m_{ia}=f_i^e(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a})$，则*

$$F_i^e-F_{ia}^e=u_{ia}(\{\widehat{m}_{bi}\}_{b\in\partial i\setminus a})\equiv\min_{x_i}\sum_{b\in\partial i\setminus a}\widehat{m}_{bi}(x_i). \tag{19.88}$$

$$F_a^e-F_{ia}^e=\widehat{u}_{ai}(\{m_{ja}\}_{j\in\partial a\setminus i})\equiv\min_{x_{\partial a}}\left[E_a(x_{\partial a})+\sum_{k\in\partial a\setminus i}m_{ka}(x_k)\right]. \tag{19.89}$$

第二式相应假设源文所写的 $\widehat{m}_{ai}=f_a^e(\{m_{ja}\}_{j\in\partial a\setminus i})$；这里的更新函数未带帽，仍照录。

命题 19.7. *SP(y) 方程为*

$$Q_{ia}(m_{ia})\cong\sum_{\{\widehat{m}_{bi}\}}\mathbb{I}[m_{ia}=g_i^e(\{\widehat{m}_{bi}\})]e^{-yu_{ia}(\{\widehat{m}_{bi}\})}\prod_{b\in\partial i\setminus a}\widehat{Q}_{bi}(\widehat{m}_{bi}), \tag{19.90}$$

$$\widehat{Q}_{ai}(\widehat{m}_{ai})\cong\sum_{\{m_{ja}\}}\mathbb{I}[\widehat{m}_{ai}=f_a^e(\{m_{ja}\})]e^{-y\widehat{u}_{ai}(\{m_{ja}\})}\prod_{j\in\partial a\setminus i}Q_{ja}(m_{ja}). \tag{19.91}$$

输入集合仍分别略写 $b\in\partial i\setminus a$、$j\in\partial a\setminus i$。

下文专将 $y=\infty$ 的情形称为调查传播（SP）。源式 g_i^e, f_a^e 与前文函数记号的差异仍保留。

19.5.2 能量复杂度

辅助模型的 Bethe 自由熵计数最小和不动点：

$$F^{\mathrm{RSB},e}=\sum_a F_a^{\mathrm{RSB},e}+\sum_i F_i^{\mathrm{RSB},e}-\sum_{(ia)} F_{ia}^{\mathrm{RSB},e}, \tag{19.92}$$

$$F_a^{\mathrm{RSB},e}=\log\left\{\sum_{\{m_{ia}\}} e^{-yF_a^e(\{m_{ia}\})}\prod_{i\in\partial a} Q_{ia}(m_{ia})\right\}, \tag{19.93}$$

$$F_i^{\mathrm{RSB},e}=\log\left\{\sum_{\{\widehat{m}_{ai}\}} e^{-yF_i^e(\{\widehat{m}_{ai}\})}\prod_{a\in\partial i} \widehat{Q}_{ai}(\widehat{m}_{ai})\right\}, \tag{19.94}$$

$$F_{ia}^{\mathrm{RSB},e}=\log\left\{\sum_{m_{ia},\widehat{m}_{ai}} e^{-yF_{ia}^e(m_{ia},\widehat{m}_{ai})}Q_{ia}(m_{ia})\widehat{Q}_{ai}(\widehat{m}_{ai})\right\}. \tag{19.95}$$

即在原式中处处以 $-F^e$ 代 F、以 y 代 x。假设 Bethe 表达式给出正确辅助自由熵，大 N 时 $F^{\mathrm{RSB},e}=N\mathcal{F}^e(y)+o(N)$，Legendre 关系为

$$\mathcal{F}^e(\{Q,\widehat{Q}\})=\Sigma^e(\epsilon)-y\epsilon, \qquad \frac{\partial\Sigma^e}{\partial\epsilon}=y. \tag{19.96}$$

1RSB 种群动力学也可近似采样随机图模型中的 SP(y) 消息。

19.5.3 约束满足与二值变量

约束满足的能量是违反约束数，每个 E_a 为 0 或 1。最小和方程有因子消息取 $\{0,1\}$ 的解，而变量消息只须保留在此集合上的投影。于是消息共有 $2^{|\mathcal{X}|}-1$ 种可能（全 1 消息因归一化不能出现），$Q,\widehat{Q}$ 是原文所称 “$2^{|\mathcal{X}|}-1$ 维单纯形” 中的点。[5]

按警告解释最小和消息，SP(y) 就追踪纯态间警告的统计，可直接推出更新，无须完整 1RSB 形式。对二值变量，投影后的消息 $(\widehat{m}(0),\widehat{m}(1))$ 有 $(0,1),(1,0),(0,0)$ 三值，分别简记 0、1、$*$，意为 “取 0” “取 1” “任取”。

变量 i 发给 a 的警告，依赖其余入消息。若三类数为 $\widehat{n}_0,\widehat{n}_1,\widehat{n}_*$，则较多 0 时输出 0，较多 1 时输出 1，相等时输出 $*$；矛盾数为 $F_i^e-F_{ia}^e=u_{ia}=\min(\widehat{n}_1,\widehat{n}_0)$。

因子 a 发给 i 时，将其他变量按输入分为 P_*,P_0,P_1，定义

$$\Delta_P(x_i)=\min_{\{x_j\}_{j\in P_*}} E_a(x_i,\{x_j\}_{j\in P_*},\{x_k=0\}_{k\in P_0},\{x_l=1\}_{l\in P_1}). \tag{19.97}$$

输出与矛盾数 $\widehat{u}_{ai}=F_a^e-F_{ai}^e$ 为

$\Delta_P(0)$	$\Delta_P(1)$	$\widehat{m}_{ai}$	$\widehat{u}_{ai}$
0	0	$*$	0
0	1	0	0
1	0	1	0
1	1	$*$	1

[5]译注：若类别数为 $2^{|\mathcal{X}|}-1$，相应概率单纯形的仿射维数应为 $2^{|\mathcal{X}|}-2$；源维数措辞保留。

对节点的每种输入警告构型，已有输出 OUT(input) 与矛盾数 $\delta F^e(\text{input})$。按输入调查独立抽样所得概率记 $P(\text{input})$，则输出调查为

$$P(\text{output}) \cong \sum_{\text{input}} P(\text{input})\mathbb{I}[\text{OUT}(\text{input}) = \text{output}]e^{-y\delta F^e(\text{input})}. \tag{19.98}$$

节点类型决定它是 Q_{ia} 或 $\widehat{Q}_{ai}$。WP 不动点的 Bethe 能量等于总矛盾数：因子矛盾数加变量矛盾数，再减去两个方向警告相互矛盾的边数，以免重复计数。因此辅助自由熵确按应有的矛盾数给每个 WP 不动点赋权。

19.5.4 再看 XORSAT

对随机 K-XORSAT，取

$$E_a(x_{\partial a}) = \begin{cases} 0, & x_{i_1(a)} \oplus \cdots \oplus x_{i_K(a)} = b_a, \\ 1, & \text{其他情形.} \end{cases} \tag{19.99}$$

可使用上述简化形式及种群动力学计算 $\mathcal{F}^e(y)$。这里仅给 $K = 3$ 的结果。须注意，此处估计最少违反约束数，最有意义的是 UNSAT 区 $\alpha > \alpha_s$；前节研究的是 SAT 区的解上均匀测度。

SP(y) 总有各边 $Q_{ia}(*) = 1$ 的解，原文说这指示最小和有唯一解；相应密度演化不动点的 $\mathcal{F}^e$ 与 y 无关。小于依赖 α 的 $y_*(\alpha)$ 时，作者只找到此解；更大 y 时存在非平凡解，见图 19.4。**译注：** 平凡调查解的存在本身，并不排除同一实例还有其他最小和不动点；原文的唯一性解释保留，应与后句“只找到”及稳定性范围区别。

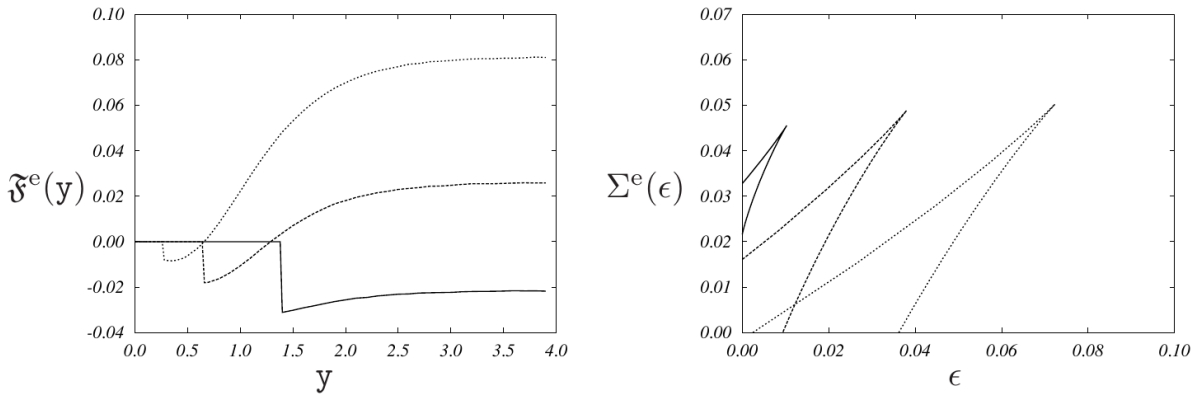


图 19.4: 随机 3-XORSAT，$\alpha = 0.87, 0.97, 1.07$；$\alpha_d \simeq 0.818$、$\alpha_s \simeq 0.918$。左：以种群动力学得到的 $\mathcal{F}^e(y)$，原参数为 $\mathcal{N} = 2 \cdot 10^4, t = 5 \cdot 10^3$，$\alpha$ 从下到上增大。右：能量复杂度随每变量违反约束数变化，α 从左到右增大。

阈值以上，密度演化收敛到非平凡 1RSB 不动点。由 Legendre 变换可参数地绘制 (ϵ, Σ^e)，须对 $\mathcal{F}^e(y)$ 求导。有三种方式：解析地对 $F^{\text{RSB},e}$ 求导，所得为不动点消息分布泛函；拟合数值函数再求导；或用相邻 y 的差分。本例用第二种，拟合 $F_{\text{fit}}(y) = a + be^{-y} + ce^{-2y} + de^{-3y}$。所得曲线多值，是 $\mathcal{F}^e$ 不凹的结果；作者仅保留凹部分作物理解，称凸支不稳定、需进一步 RSB，其意义尚不明确。**译注：** 这段“凹支”的选择按源保留。精确辅助模型有 $\mathcal{F}^e(y) = N^{-1} \log \sum_n e^{-yF_n^e}$，

只要可微，其二阶导为 $N^{-1}\operatorname{Var}_y(F_n^e)\ge 0$，应为凸函数；故源中的凸凹措辞与精确配分函数约定存在张力，不能由本段视为已验证的稳定性准则。

$\alpha\in[\alpha_d,\alpha_s)$ 时，Σ^e 一直到 $\epsilon=0$ 仍为正，截距等于前章 SAT 团簇复杂度。UNSAT 区则在正 $\epsilon_{\rm gs}(K,\alpha)$ 处消失，它是随机线性系统最小违反方程的原文所谓“比例”。复杂度在另一能量密度 ϵ_d 以上没有定义，作者取 $\Sigma^e=-\infty$，解释为此区恢复仅一个 Bethe 测度的简单问题。图 19.5 给出两能量随 α 变化。**译注：**本节能量密度是每变量违反方程数；若称为全部方程中的比例，还须除以 $\alpha=M/N$。

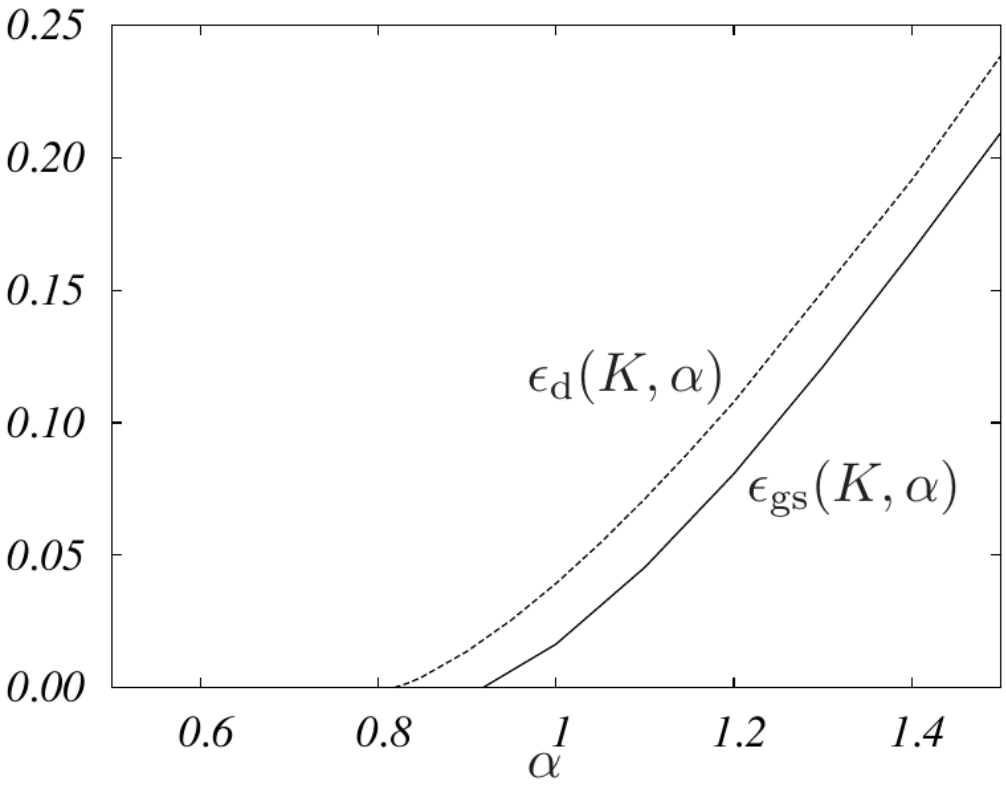


图 19.5: 随机 3-XORSAT 的渐近基态能量，即每变量最小违反约束数 $\epsilon_{\rm gs}$，在 $\alpha<\alpha_s$ 时为 0。虚线 ϵ_d 是使 $E(x)<Ne$ 的构型仍成团簇的最高能量密度；$\alpha<\alpha_d$ 时为 0。

19.6 1RSB 相的性质

前面计算了复杂度及其零温能量版本。现在由极端态分解讨论随机图模型测度的定性性质：

$$\mu(x)=\sum_{n\in\mathcal{E}} w_n\mu_n(x). \tag{19.100}$$

假设 2、3 意味着，仅保留自由熵密度 $\varphi_n\simeq\varphi_*$ 的态，误差可忽略，其中

$$\varphi_*=\arg\max\{\varphi+\Sigma(\varphi):\Sigma(\varphi)\ge 0\}. \tag{19.101}$$

一般 Σ 在 $[\varphi_{\min},\varphi_{\max}]$ 内严格正且连续，端点 $\Sigma(\varphi_{\max})=0$，附近有

$$\Sigma(\varphi)=x_*(\varphi_{\max}-\varphi)+O((\varphi_{\max}-\varphi)^2). \tag{19.102}$$

最优点在区间内部、复杂度为正时是 d1RSB；在右端点、复杂度为 0 时是 s1RSB，原文称后一情形当且仅当 $x_* \le 1$，见图 19.6。

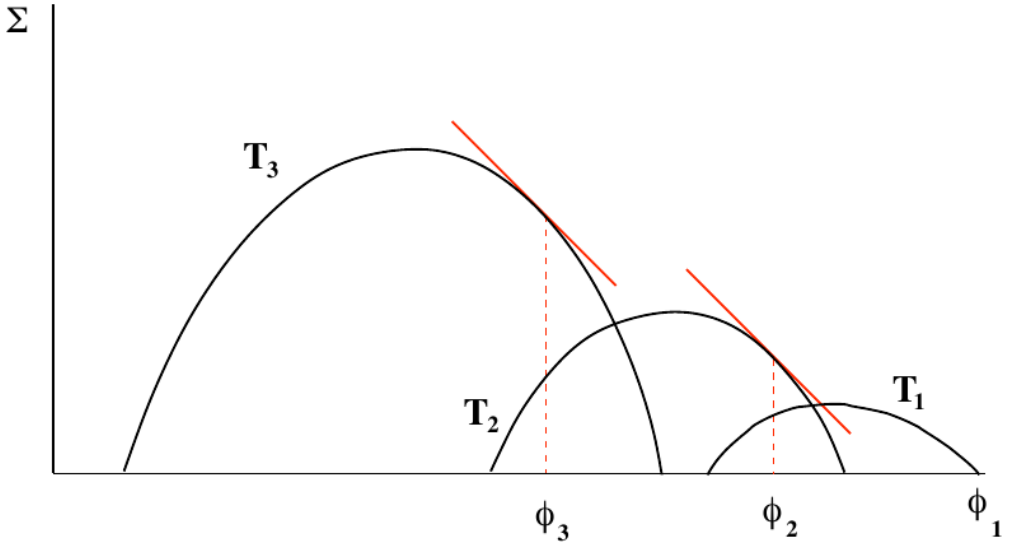


图 19.6: 有限温度 1RSB 转变中，$T_1 < T_2 < T_3$ 时复杂度与自由熵密度示意。服从 μ 的随机构型以高概率位于密度分别为 $\varphi_1, \varphi_2, \varphi_3$ 的团簇。T_2, T_3 高于凝聚转变，对应 $\partial\Sigma/\partial\varphi = -1$；$T_1$ 低于凝聚转变，φ_1 为复杂度正区域的最大自由熵。

19.6.1 动力学 1RSB

设 $\Sigma_* = \Sigma(\varphi_*) > 0$。允许指数小误差时，可仅求和 $\varphi_n \in [\varphi_* - \varepsilon, \varphi_* + \varepsilon]$ 的态。其数在领先指数阶为 $e^{N\Sigma_*}$，权重在 $[e^{-N(\Sigma_*+\varepsilon')}, e^{-N(\Sigma_*-\varepsilon')}]$。

预期不同态支撑基本不交，即存在构型空间子集 $\{\Omega_n\}$，使对任意 $m \in \mathcal{E}$，

$$\mu_m(\Omega_m) \simeq 1, \qquad \sum_{n\in\mathcal{E}\setminus m} w_n \mu_n(\Omega_m) \simeq 0. \tag{19.103}$$

不同态间还有“大自由能垒”：可将分割选到边界只携带随 N 指数小的概率质量。这导致两个重要结果。

玻璃态动力学。考虑对 μ 满足细致平衡的局域 Markov 动力学，例如 Glauber。为排除平凡不可约性障碍，可假设 ψ_a 有正下界。从已平衡的 $x(0) \sim \mu$ 出发，基本相当于在典型态间均匀选 n，再从 μ_n 采样。指数大能垒使动力学在 Ω_n 内停留指数长时间，仅在更长时间尺度才在态间平衡。

令 $D(x, x')$ 为 Hamming 距离。分别从 μ、从同一个 μ_n 抽两独立构型，其平均距离为 Nd_0, Nd_1；预期大系统中 d_1 渐近不依赖按 w_n 抽到的态，并有 $d_1 < d_0$。令 $d(t) = \langle D(x(0), x(t))\rangle/N$，则任意 $\varepsilon < d_0 - d_1$ 的关联时间

$$\tau(\varepsilon) = \inf\{t : d(t) \ge d_0 - \varepsilon\}$$

预期随 N 指数大。

有限维投影中的短程关联。1RSB 由多态分解引入长程关联，但探测有界数量变量却不能看到它。对均匀随机的 $i(1),\dots,i(k)$，d1RSB 中有

$$\mathbb{E}\left|\left\langle\prod_{j=1}^{k} f_j(x_{i(j)})\right\rangle - \prod_{j=1}^{k}\langle f_j(x_{i(j)})\rangle\right| \longrightarrow 0.$$

内平均对 μ 取，外期望对随机图模型取。直觉是：若这 k 个变量有长程关联，则固定其中 $k-1$ 个会改变最后一个的边缘；而远变量相联是因全系统处于同一态，有界数量变量不能在 $e^{N\Sigma_*}$ 个相关态中作有意义的选择，故不能改变该边缘。

另一论证看两独立构型的距离：它依概率集中，因为二者以高概率处于不同态（同态概率为 $e^{-N\Sigma_*}$），不同态间距离弱依赖态对。有限变量集缺乏长程关联，也与 μ 本身仍为非极端 Bethe 测度一致：每个 BP 方程只涉及有界变量集，只会因这些变量的关联而失效。第 22 章将用更精细的点到集关联探测 d1RSB 长程关联。

19.6.2 静态 1RSB

此时分解由少数自由熵近最大的态主导。令 $\varphi_n = \varphi_{\max} + s_n/N$ 放大边缘，则偏移 s_n 形成密度 $e^{-x_* s}$ 的点过程。与低于临界温度的 REM 类似，预期权重趋于同一普适 Poisson–Dirichlet 过程，仅通过 x_* 依赖模型细节；第 8 章已从复本方法讨论这种普适性。两独立复本所属态 n_1, n_2 相同的概率满足

$$\mathbb{E}\mathbb{P}_\mu(n_1 = n_2) = \mathbb{E}\sum_{n\in\mathcal{E}} w_n^2 = 1 - x_*. \tag{19.104}$$

期望对随机图取。于是复本距离不集中、重叠分布非平凡，这要求远距离二点关联不消失。这类关联使 BP 失效：原测度不再是 Bethe 测度，其局域边缘无法用一套消息描述，必须采用多个 Bethe 测度的凸组合。

但前面用“正确”$x=1$ 权重，平均边缘仍满足 BP，如何解释？s1RSB 中，$x=1$ 虽为态赋权的正确值，却不是腔方程应使用的参数。源文说明，若复杂度为凸函数，且边缘斜率 $-x_* > -1$，则对任意 $x \ge x_*$，原最优化与

$$\varphi_* = \arg\max\{x\varphi + \Sigma(\varphi) : \Sigma(\varphi) \ge 0\} \tag{19.105}$$

有相同结果，选中同一组态。但限制 $\Sigma \ge 0$ 不能局域实施，不出现在腔方程中；若用 $x > x_*$，会算出必须拒绝的负复杂度，作者认为它与指数稀有实例有关。为留在非负复杂度区域，腔计算须取 $x \le x_*$；又要选出 $\varphi_{\max}$ 的态，故应取 $x = x_*$。**译注：**此段“凸函数”的源措辞保留；从单个端点斜率推出全部 $x \ge x_*$ 的全局最优结论，还须满足适当的全局支撑条件，不能仅由端点展开无条件推出。此处不另替作者改定复杂度的凸凹约定。

19.6.3 1RSB 何时失效？

即使局部树状、系统很大，1RSB 也未必正确。核心假设是：枚举 BP 不动点的辅助图模型用简单 BP 就渐近精确，即辅助问题为 RS 而无玻璃相。随机 XORSAT 或接近 SAT–UNSAT 阈值的 SAT 等某些情形如此，其他情形则可能失效。

若辅助测度也分解成许多 Bethe 态，BP 便不能正确描述它；须引入第二层辅助模型，处理第一辅助模型的多个 BP 不动点，这称两步 RSB。必要时可继续至 R 层，称 R-RSB；连续或完全 RSB 对应大 R 极限。概念上、至少启发式上清楚，但技术上很困难；超越 1RSB 的结果仍有限，第 22 章略作概述。

附录：XORSAT 的 SP(y) 方程

本附录给出随机 XORSAT 能量形式的技术细节，特别导出大 y 辅助自由熵与小能量复杂度。可视为 SP(y) 应用练习，略去许多细节，只列主要中间结果。

利用 0、1 对称性，以一参数表示每个调查：$Q_{ia}(0)=Q_{ia}(1)=\zeta_{ia}/2$、$Q_{ia}(*)=1-\zeta_{ia}$；带帽调查相应为 $\widehat{Q}_{ai}(0)=\widehat{Q}_{ai}(1)=\eta_{ai}/2$、$\widehat{Q}_{ai}(*)=1-\eta_{ai}$。因子更新为

$$\eta_{ai}=\prod_{j\in\partial a\setminus i}\zeta_{ja}. \tag{19.106}$$

变量更新较复杂。令输入参数集 $\eta=\{\eta_{bi}:b\in\partial i\setminus a\}$，定义

$$B_q(\eta)=\sum_{S\subset\{\partial i\setminus a\}}\mathbb{I}(|S|=q)\prod_{b\in\partial i\setminus\{S\cup\{a\}\}}(1-\eta_{bi})\prod_{c\in S}\eta_{cj}, \tag{19.107}$$

并令 $A_{q,r}(\eta)=B_{q+r}(\eta)\binom{q+r}{q}2^{-(q+r)}$。可得

$$\zeta_{ia}=\frac{2\sum_{q=0}^{|\partial i|-2}\sum_{r=q+1}^{|\partial i|-1}A_{q,r}(\eta)e^{-yq}}{\sum_{q=0}^{\lfloor(|\partial i|-1)/2\rfloor}A_{q,q}(\eta)e^{-yq}+2\sum_{q=0}^{|\partial i|-2}\sum_{r=q+1}^{|\partial i|-1}A_{q,r}(\eta)e^{-yq}}. \tag{19.108}$$

译注： 源式 (19.107) 末项指标为 η_{cj}，与输入定义的 η_{ci} 不一致；集合的括号写法也照录，未隐改。式 (19.108) 的无效高阶计数应由 $B_{q+r}=0$ 理解。

辅助自由熵各项为

$$e^{F_a^{\mathrm{RSB},e}}=1-\frac{1}{2}(1-e^{-y})\prod_{i\in\partial a}\zeta_{ia},\qquad e^{F_{ai}^{\mathrm{RSB},e}}=1-\frac{1}{2}\eta_{ai}\zeta_{ia}(1-e^{-y}),$$
$$e^{F_i^{\mathrm{RSB},e}}=\sum_{q=0}^{d_i}\sum_{r=0}^{d_i-q}A_{q,r}(\{\eta_{ai}\}_{a\in\partial i})e^{-y\min(q,r)}. \tag{19.109}$$

随机实例中，两更新成为随机边上 η,ζ 分布的递推，可用种群动力学近似，鼓励读者实现并估计自由熵。

大 y 时，在下述可数值检验的定性假设下，可作解析控制：以概率 t 有 $\eta=0$，否则 $\eta=1-e^{-y}\widehat{\eta}$；以概率 s 有 $\zeta=0$，否则 $\zeta=1-e^{-y}\widehat{\zeta}$。$t,s$ 均趋于 $(0,1)$ 内极限，$\widehat{\eta},\widehat{\zeta}$ 趋于支撑在 $[0,\infty)$ 的随机变量。下面保留至 e^{-y} 一阶，并用同样符号表示极限量。

易得 $1-t=(1-s)^{k-1}$、$s=e^{-K\alpha(1-t)}$，与先前不动点方程相同，故 $t=1-\widehat{Q}_*$、$s=1-Q_*$。因子更新给出

$$\widehat{\eta}\overset{d}{=}\widehat{\zeta}_1+\cdots+\widehat{\zeta}_{K-1}, \tag{19.110}$$

其中各项独立同分布。

变量更新有 l 个输入，l 为均值 $K\alpha$ 的 Poisson 变量。源文令 m 为 $\eta=0$ 的入消息数，并称 $m=0$ 导致 $\zeta=0$、已包含在 s,t 关系中。条件在 $m\geq 1$，

$$\mathbb{P}(m)=\frac{\lambda^m}{m!}e^{-\lambda}\frac{1}{1-e^{-\lambda}}\mathbb{I}(m\geq 1),\qquad \lambda=K\alpha(1-t). \tag{19.111}$$

此时 $m=1$ 给 $\widehat{\zeta}\overset{d}{=}\widehat{\eta}$；$m=2$ 给 $\widehat{\zeta}=1$；$m\geq 3$ 给 $\widehat{\zeta}=0$。**译注：**按前文定义，t 是 $\eta=0$ 的概率，故“$\eta=0$ 的数量”均值应为 $K\alpha t$，而源式 (19.111) 用 $K\alpha(1-t)$。其后分类与无非零警告时输出 $\zeta=0$ 的含义，提示应核对原句的零/非零，不能将此不一致隐藏。

各自由熵密度贡献展开为

$$f_f^{\mathrm{RSB},e}=(1-s)^k[-\log 2+e^{-y}(1+K\langle\widehat{\zeta}\rangle)]+o(e^{-y}), \tag{19.112}$$

$$\begin{aligned}f_v^{\mathrm{RSB},e}=&\frac{\lambda^2}{2}e^{-\lambda}[-\log 2+e^{-y}(1+2\langle\widehat{\eta}\rangle)]\\&+\sum_{m=3}^{\infty}\frac{\lambda^m}{m!}e^{-\lambda}[(1-m)\log 2+e^{-y}m(1+\langle\widehat{\eta}\rangle)]+o(e^{-y}),\end{aligned} \tag{19.113}$$

$$f_e^{\mathrm{RSB},e}=(1-t)(1-s)[-\log 2+e^{-y}(1+\langle\widehat{\eta}\rangle+\langle\widehat{\zeta}\rangle)]+o(e^{-y}). \tag{19.114}$$

尖括号为相应期望。源文将总密度写为 $\mathcal{F}^e(y)=f_f^{\mathrm{RSB},e}+\alpha f_v^{\mathrm{RSB},e}-K\alpha f_e^{\mathrm{RSB},e}=\Sigma_0+e^{-y}\epsilon_0+o(e^{-y})$，其中

$$\Sigma_0=\left[1-\frac{\lambda}{k}-e^{-\lambda}\left(1+\frac{k-1}{k}\lambda\right)\right]\log 2, \tag{19.115}$$

$$\epsilon_0=\frac{\lambda}{k}\left[1-e^{-\lambda}\left(1+\frac{k}{2}\lambda\right)\right]. \tag{19.116}$$

译注：此处源总和将 f_f 与 f_v 的密度系数位置写成 $1,\alpha$，与式 (19.38) 的变量项系数 1、因子项系数 α 不一致；原式及后续结果保留，不据此认证展开。

由 Legendre 变换，$\epsilon\to 0$ 时

$$\Sigma^e(\epsilon)=\Sigma_0+\epsilon\log\frac{\epsilon_0 e}{\epsilon}+o(\epsilon). \tag{19.117}$$

特别地，SAT–UNSAT 附近 $0<\alpha-\alpha_s\ll 1$ 时，基态能量密度正比于 $(\alpha-\alpha_s)/|\log(\alpha-\alpha_s)|$。

习题 19.7. 另一极端，大 α 时证明 $\epsilon_{\mathrm{gs}}(K,\alpha)=\alpha/2+\sqrt{2\alpha}\,\epsilon_*(K)+o(\sqrt{\alpha})$，其中正数 $\epsilon_*(K)$ 为第 8 章全连接 K-自旋模型基态能量的绝对值。这说明本章 $M=\Theta(N)$ 与复本方法处理的 $M=\Theta(N^{K-1})$ 之间没有有趣的中间渐近区域。

译注：原题的正号照录。对任意含非空变量集的异或约束，均匀构型的期望违反数是 $M/2$，故最小违反数至多 $M/2$，即 $\epsilon_{\mathrm{gs}}\leq\alpha/2$；正 ϵ_* 的原渐近式与此界不符。未将原题静默改为负号。

注释

腔方法起初是在研究 Sherrington–Kirkpatrick 模型时，作为复本方法的替代途径提出（Mézard、Parisi 和 Virasoro，1985b）。局部树状图的 1RSB 腔方法先在自旋玻璃中发展（Mézard 和 Parisi，2001）；零温、即计数最小和解的应用也先在自旋玻璃中描述（Mézard 和

Parisi，2003）。本章范围不同于那些更侧重随机实例平均的工作。Bethe 测度的严格处理见 Dembo 和 Montanari（2008b）。

在辅助模型上应用 BP 等价于 1RSB 腔方法，这一想法已出现在 $y = 0$ 的着色和可满足性研究中（Parisi，2002；Braunstein 和 Zecchina，2004；Maneva、Mossel 和 Wainwright，2005）。本章推广这些工作，重要区别是辅助模型变量是消息，而非节点量。

$x = 1$ 与树上重构密切相关。Mézard 和 Montanari（2006）给出定理 19.5 的证明及习题 19.6 的自由熵表达式。

单实例 SP(y) 方程首先出现在 K-SAT 中（Mézard 和 Zecchina，2002；另见 Mézard、Parisi 和 Zecchina，2003）。二值问题中直接由警告导出 SP(y) 的方法，最初用于可满足性（Braunstein、Mézard 和 Zecchina，2005；另见 Braunstein 和 Zecchina，2004；Maneva、Mossel 和 Wainwright，2005）。XORSAT 的 1RSB 分析及与精确结果的比较见 Mézard、Ricci-Tersenghi 和 Zecchina（2003）。

另一路径是第 8 章复本方法，起初用于全连接、即完全图模型（Mézard、Parisi 和 Virasoro，1987），后推广到稀疏随机图（Mézard 和 Parisi，1985；Dominicis 和 Mottishaw，1987；Mottishaw 和 Dominicis，1987；Wong 和 Sherrington，1988；Goldschmidt 和 Lai，1990）。Monasson（1998）进一步改善技术，并提供了清楚的介绍。

第二十章　随机 K-可满足性

本章将腔方法用于随机 K-SAT，研究相图、特别是 SAT–UNSAT 阈值，以及消息传递的算法应用。全章推导是启发式的；原稿写作时，其严格化仍在起步阶段，猜想相图与算法效率尚无完整严格证实。算得的 $\alpha_s(K)$ 被猜想为精确，所述低复杂度算法在找解中表现很好。这些是源稿当时的证据与判断，译稿不将其更新成新的定理。

第 20.1 节写出 BP 方程，其统计分析给出首个 RS 阈值估计，但这一估计错误，因为接近 SAT–UNSAT 转变时 RS 假设不成立；更低密度先发生结构转变。尽管如此，BP 在广泛密度区间经验上收敛，只要不太接近阈值，可用它引导逐次固定变量的消元过程，求解大型实例。第 20.2 节用 1RSB 及 SP 得到表 20.1 的阈值，并介绍调查引导消元；原稿称它是当时求解临界附近大型随机可满足实例最有效的算法。

本章限 $K \geq 3$。$K = 2$ 可多项式判定，转变机制不同，阈值为 1；$K = 3$ 与 $K \geq 4$ 也有更细微的定性区别，故并用 3-SAT、4-SAT 说明。第 20.4 节介绍相似的随机图着色，说明同样技术的应用。

20.1　信念传播与复本对称分析

第 10 章已给出若干严格阈值界。现在用消息传递。M 个子句由 $a, b \in \{1, \dots, M\}$ 标记，N 个二值变量为 $x_i \in \{0, 1\}$；∂a 是子句变量集，∂i 是变量出现的子句集。变量以否定形式出现时 $J_{ai} = 1$，否则为 0。定义 $\partial_0 a, \partial_1 a$ 为对应 $J_{ai} = 0, 1$ 的变量集，$\partial_0 i, \partial_1 i$ 类似。子句满足的示性函数记 ψ_a，对 SAT 实例研究均匀解测度

$$\mu(x) = \frac{1}{Z} \prod_{a=1}^{M} \psi_a(x_{\partial a}). \tag{20.1}$$

图中 $J_{ai} = 1$ 用虚线、为 0 用实线。

20.1.1　BP 方程

为简写、分析和实现，固定边 (i, a) 后把邻域分为 $\{a\} \cup S_{ia} \cup U_{ia}$：

$$\begin{aligned} J_{ai} = 0: &\quad S_{ia} = \partial_0 i \setminus \{a\},\ U_{ia} = \partial_1 i, \\ J_{ai} = 1: &\quad S_{ia} = \partial_1 i \setminus \{a\},\ U_{ai} = \partial_0 i. \end{aligned} \tag{20.2}$$

译注： 源第二行写 U_{ai}，与其余 U_{ia} 约定相反，照录。

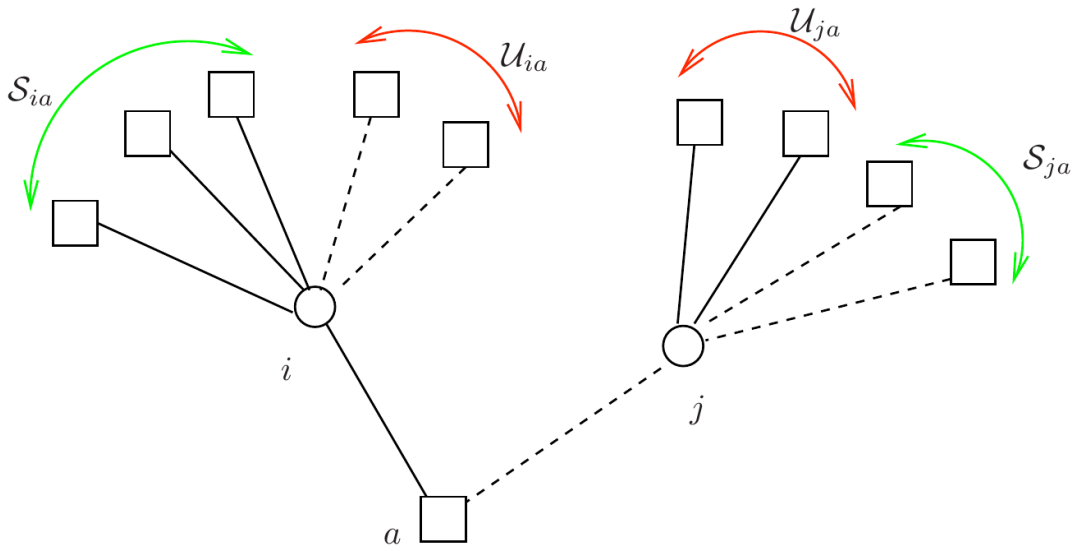


图 20.1: S_{ia} 包含除 a 外满足 $J_{bi}=J_{ai}$ 的子句；U_{ia} 包含 $J_{bi}=1-J_{ai}$ 的子句。

每个二值 BP 消息可用一实数表示。令 $\zeta_{ia}=\nu_{i\to a}(x_i=J_{ai})$、$\widehat{\zeta}_{ai}=\widehat{\nu}_{a\to i}(x_i=J_{ai})$，另一分量分别为 $1-\zeta_{ia}$、$1-\widehat{\zeta}_{ai}$。不动点方程为

$$\begin{aligned}\zeta_{ia}&=\frac{\prod_{b\in S_{ia}}\widehat{\zeta}_{bi}\prod_{b\in U_{ia}}(1-\widehat{\zeta}_{bi})}{\prod_{b\in S_{ia}}\widehat{\zeta}_{bi}\prod_{b\in U_{ia}}(1-\widehat{\zeta}_{bi})+\prod_{b\in U_{ia}}\widehat{\zeta}_{bi}\prod_{b\in S_{ia}}(1-\widehat{\zeta}_{bi})},\\ \widehat{\zeta}_{ai}&=\frac{1-\prod_{j\in\partial a\setminus i}\zeta_{ja}}{2-\prod_{j\in\partial a\setminus i}\zeta_{ja}}.\end{aligned}\tag{20.3}$$

空乘积为 1。计算两右端分别需 $O(|\partial i|)$、$O(|\partial a|)$ 次运算；一般 BP 的因子更新需 $O(2^{|\partial a|})$。Bethe 自由熵仍为 $F=\sum_a F_a+\sum_i F_i-\sum_{(ia)}F_{ia}$，各项为

$$F_a=\log\left(1-\prod_{i\in\partial a}\zeta_{ia}\right),$$

$$F_i=\log\left[\prod_{a\in\partial_0 i}\widehat{\zeta}_{ai}\prod_{b\in\partial_1 i}(1-\widehat{\zeta}_{bi})+\prod_{a\in\partial_0 i}(1-\widehat{\zeta}_{ai})\prod_{b\in\partial_1 i}\widehat{\zeta}_{bi}\right],$$

$$F_{ai}=\log[(1-\zeta_{ia})(1-\widehat{\zeta}_{ai})+\zeta_{ia}\widehat{\zeta}_{ai}].\tag{20.4}$$

$$\nu_i(x_i)\cong\prod_{a\in\partial i}\widehat{\nu}_{a\to i}(x_i).\tag{20.5}$$

最后一式给单点边缘估计。

20.1.2 统计分析

随机公式均匀取 $M=N\alpha$ 个子句，因子图服从 $G_N(K,M)$。$|\partial_0 i|,|\partial_1 i|$ 渐近为独立、均值 $K\alpha/2$ 的 Poisson 变量。假定有近似不动点，RS 假设下随机边的消息依分布趋于满足

$$\widehat{\zeta}\overset{d}{=}\frac{1-\zeta_1\cdots\zeta_{K-1}}{2-\zeta_1\cdots\zeta_{K-1}},\tag{20.6}$$

$$\zeta\overset{d}{=}\frac{\prod_{b=1}^{p}\widehat{\zeta}_b\prod_{b=p+1}^{p+q}(1-\widehat{\zeta}_b)}{\prod_{b=1}^{p}\widehat{\zeta}_b\prod_{b=p+1}^{p+q}(1-\widehat{\zeta}_b)+\prod_{b=1}^{p}(1-\widehat{\zeta}_b)\prod_{b=p+1}^{p+q}\widehat{\zeta}_b}.\tag{20.7}$$

p,q 独立 Poisson，均值 $K\alpha/2$；两组输入分别是 $\zeta,\widehat{\zeta}$ 的独立副本。可用种群动力学近似这些分布并估计自由熵。

习题 20.1. *在 RS 假设内说明 $F/N\to f^{\mathrm{RS}}=f_v^{\mathrm{RS}}+\alpha f_c^{\mathrm{RS}}-K\alpha f_e^{\mathrm{RS}}$，其中*

$$
\begin{aligned}
f_v^{\mathrm{RS}} &= \mathbb{E}\log\left[\prod_{a=1}^{p}\widehat{\zeta}_a\prod_{a=p+1}^{p+q}(1-\widehat{\zeta}_a)+\prod_{a=1}^{p}(1-\widehat{\zeta}_a)\prod_{a=p+1}^{p+q}\widehat{\zeta}_a\right],\\
f_c^{\mathrm{RS}} &= \mathbb{E}\log[1-\zeta_1\cdots\zeta_{K-1}],\\
f_e^{\mathrm{RS}} &= \mathbb{E}\log[(1-\zeta_1)(1-\widehat{\zeta}_1)+\zeta_1\widehat{\zeta}_1].
\end{aligned}
\tag{20.8}
$$

期望对 $\zeta_1,\dots,\zeta_K$、$\widehat{\zeta}_1,\dots,\widehat{\zeta}_{p+q}$ 的独立副本及独立 Poisson p,q 取。

译注：源因子项写 $K-1$ 个输入，但式 (20.4) 的完整因子有 K 个，题末也列到 ζ_K；此处照录原式并标出。

图 20.2 是 3-SAT 数值例。每个网格密度用 10^4 种群、$3\cdot10^3$ 次迭代，初消息在 $(0,1)$ 均匀，前 10^3 次不计入自由熵。预测熵在 $\alpha\le\alpha_*(K)$ 时正且下降，原正文给 $\alpha_*(3)\simeq4.6773$。更高密度，分布方程似乎不再有 $[0,1]$ 内的解，数值上表现为变量更新分母变零。因此 α_* 是 RS 给出的 SAT–UNSAT 阈值预测，也可不用种群动力学计算。

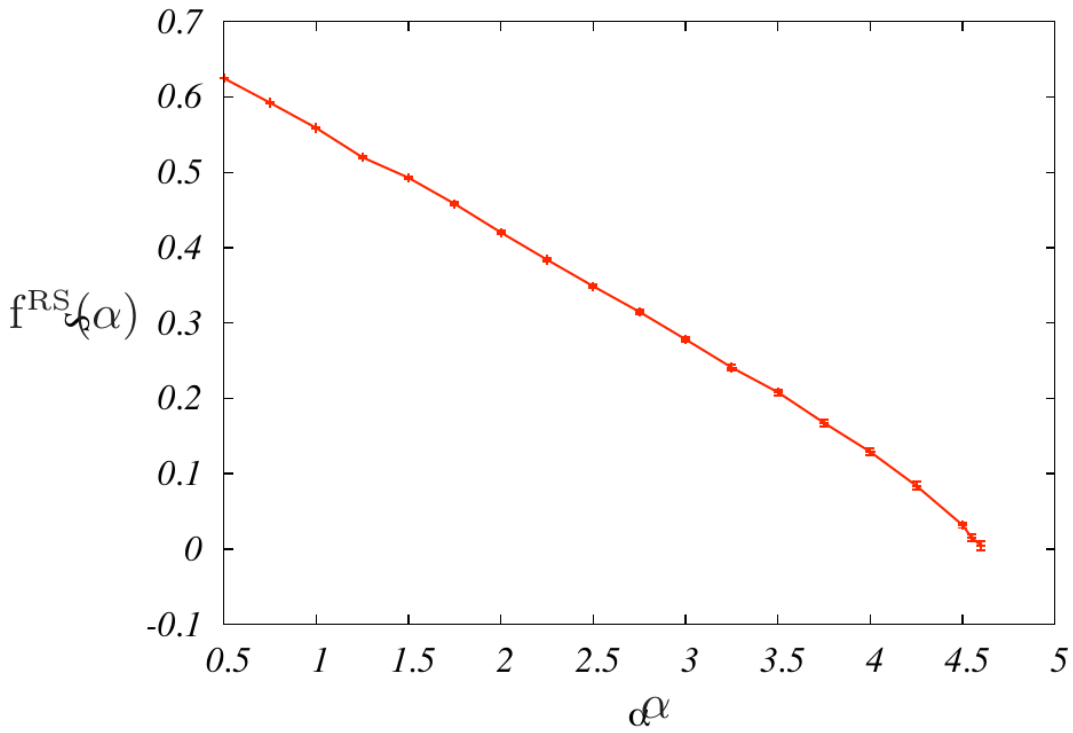


图 20.2: 随机 3-SAT 的 RS 渐近熵密度预测；预期在 $\alpha\le\alpha_c(3)=\alpha_d(3)\simeq3.86$ 正确。

习题 20.2. *计算 $\alpha_*(K)$。思路是超过此密度，任何 RS 分布方程解都有正概率 $\widehat{\zeta}=0$，使变量更新分母以正概率变零而矛盾。先以 $\max(\widehat{\zeta}_i,\varepsilon)$ 正则化；记 x 为 $\widehat{\zeta}$ 是 ε 量级的概率，y 为 ζ 是 $1-\varepsilon$ 量级的概率，再令 $\varepsilon\to0$。*

(a) *证明 $x=y^{K-1}$。*

(b) 证明 $1-2y = e^{-K\alpha x} I_0(K\alpha x)$，其中 $I_0(t) = \sum_{p=0}^{\infty} (t/2)^{2p}/(p!)^2$。提示：前 p 个输入中有 p' 个、后 q 个有 q' 个为 ε 量级，则 $p' > q'$ 时 $\zeta = O(\varepsilon)$，$p' < q'$ 时 $\zeta = 1 - O(\varepsilon)$，相等时 $\zeta = O(1)$。

(c) 令 α_* 是上述两式仅有 $x = y = 0$ 解的最大密度，证明 $\alpha \geq \alpha_*$ 时出现正解。

(d) 数值求得 $\alpha_*(3) \simeq 4.6673$、$\alpha_*(4) \simeq 11.83$。

译注： 源正文 4.6773 与题目 4.6673 不一致，分别保留。边界恰在临界点时是否已有非零解须由方程核定，原 (c) 的非严格不等号也未另改。

大密度 RS 结果错误：它违背第 10 章的严格上界，例如 $\alpha_{\mathrm{UB},2}(3) \simeq 4.66603$、$\alpha_{\mathrm{UB},2}(4) \simeq 10.2246$。RS 熵正确的最大密度就是凝聚阈值 α_c，后面和第 22 章继续讨论。另一检验方法是观察 BP 迭代。

20.1.3 BP 引导消元

从均匀随机消息开始迭代；当上一轮所有消息改变量均不超过 δ 时，记收敛时间 $t_*(\delta)$ 并停止。重复实验估计在 $t_{\max}$ 轮内收敛的概率。图 20.3 取 $\delta = 10^{-2}, t_{\max} = 10^3$；概率在 α_{BP} 附近骤降，对两参数变化较稳健。数值提示阈值行为：以下收敛时间随 N 有限或温和增长，以上典型实例不能在给定时限收敛。

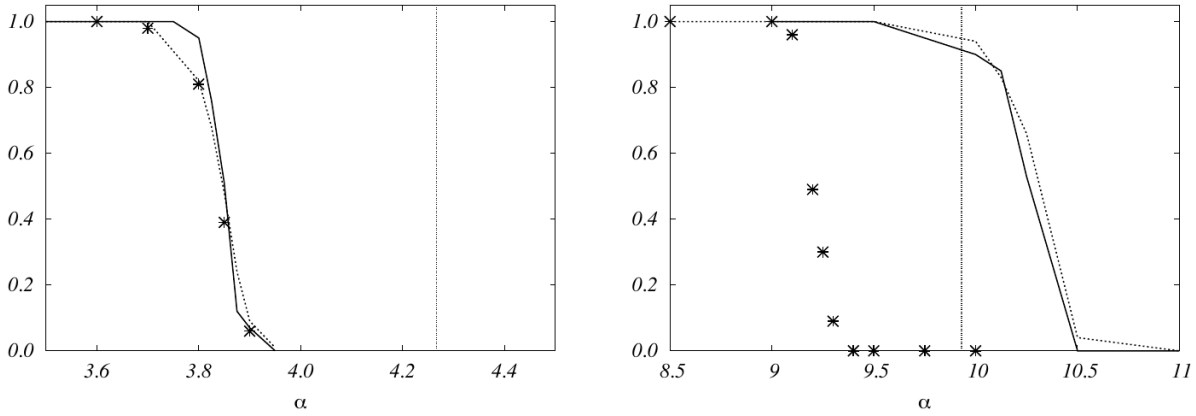


图 20.3: BP 收敛概率：左 3-SAT、右 4-SAT；100 实例，$N = 5 \cdot 10^3$ 虚线、10^4 实线。数据提示 $\alpha_{\mathrm{BP}} \simeq 3.85, 10.3$。点为 BP 引导消元找 SAT 赋值概率，图注称 100 个 $N = 5 \cdot 10^3$ 实例；竖线为 SAT–UNSAT 阈值。

BP 收敛时可引导逐次固定变量；每固定新变量前先迭代至收敛，也可更冒险地直接使用 $t_{\max}$ 时未收敛消息。须选择固定哪个变量及取什么值。本例用偏置 $\pi_i = \nu_i(0) - \nu_i(1)$：

1. 对 $n = 1, \ldots, N$ 调用 $\mathrm{BP}(F, \varepsilon, t_{\max})$；不收敛则返回“未找到”并退出。
2. 计算全部尚未固定变量偏置，选绝对值最大的 $i(n)$。
3. 若 $\pi_{i(n)} \geq 0$，固定 $x_{i(n)} = 0$，否则固定为 1；以约化后的公式替换 F，继续循环。
4. 返回赋值 x^*。

BP 伪代码见第 14 章；只要能估计边缘，其他引导方式也可使用同一消元过程。图 20.3 正文称成功率由 100 个 $N = 5 \cdot 10^4$ 实例估计。3-SAT 中几乎每次收敛都得到解，即 $\alpha \lesssim 3.85$ 成功率接近 1；4-SAT 在 $\alpha \lesssim 10.3$ 多能收敛，此值甚至超过猜想 SAT 阈值 9.931 及严格上界 10.2246，但消元仅在约 $\alpha \lesssim 9.25$ 找到解。作者相信 $K \geq 5$ 类似 4-SAT。**译注：** 成功率正文的 $5 \cdot 10^4$ 与图注 $5 \cdot 10^3$ 不同，均保留；伪代码原编号重复 8，这里以结构列表表达原步骤。

20.1.4 RS 分析的适用性

大密度 RS 失败的机制依赖 K。$K = 3$ 的 BP 不动点失稳，导致消元出错；按源第 17.4.2 节的局域稳定性分析，在 $\alpha_{\rm st}(3) \simeq 3.86$ 失稳。$K \geq 4$ 则不动点仍稳定，但边缘错误，局域稳定性不足以检验 RS。可定义稳定性阈值 $\alpha_{\rm st}$，以上没有局域稳定不动点；凝聚阈值 α_c，以上没有能正确估计局域边缘与自由熵的 BP 点。应有 $\alpha_c \leq \alpha_{\rm st}$；3-SAT 两者相同，$K \geq 4$ 严格不同。

BP 失败源于测度分解成许多纯态；这在第三个阈值 $\alpha_d \leq \alpha_c$ 发生，称动力学转变，以上 Glauber 不再有效。$\alpha_d < \alpha < \alpha_c$ 时有许多纯态、许多 BP 准解，其中一个仍给正确边缘。读者或许觉得，本为寻找一个 α_s，却很快得到原文列出的 $\alpha_d \leq \alpha_c \leq \alpha_{\rm st} \leq \alpha_s$，描述一群陌生现象。幸运的是，求正确 α_s 虽需理解纯态增殖，却无须完整精细团簇图像；能量腔方法提供一个有用的粗略捷径，完整图景见第 20.3 节。**译注：** 原阈值链中 $\alpha_{\rm st} \leq \alpha_s$ 与前面 4-SAT 在 10.3 附近仍收敛、而 $\alpha_s \simeq 9.931$ 的描述须区别：有限迭代收敛阈值、局域稳定阈值与正确边缘阈值不是同一定义，源未在此补齐相互推论条件；第 17 章正文仍缺。

20.2 调查传播与 1RSB 相

能量 1RSB 有两种动机。一方面改变问题：不求解上均匀测度边缘，改最小化

$$E(x) = \sum_{a=1}^{M} E_a(x_{\partial a}), \tag{20.9}$$

其中满足子句为 0，否则为 1。源文把 SAT 阈值称为“以上基态能量消失”的临界值；下一段却说，估计基态能量密度后发现它在某阈值以下为 0，将该阈值识别为 α_s。[1]

这还假设典型大型随机实例不存在一段密度区间，基态能量虽正却仅次线性于 N。假设合理但非普遍成立；例如附加一个 $o(N)$ 变量的小 UNSAT 子式会使整体永远 UNSAT，能量密度方法却看不出变化。

另一方面，SAT 区能量方法给出零能纯态的粗略图像：一般 Bethe 态由一套边缘消息描述，而能量形式只区分边缘是否集中于单值；集中者精确描述，其余仅记为“不集中”。

20.2.1 SP(y) 方程

二值硬约束可用前章简化 SP(y)。每个调查有 0、1、$*$ 三分量。源文称，$J_{ai} = 0$ 时 $\widehat{Q}_{ai}(1) = 0$，$J_{ai} = 1$ 时 $\widehat{Q}_{ai}(0) = 0$；其警告解释是：0 消息强迫变量取 0，而未否定子句仅能强迫取使它满足的 0。于是以非零强迫分量参数化因子调查，简记 $\widehat{Q}_{ai}$，即因子发强迫警告的概率。**译注：** 这段将 $J_{ai} = 0$ 的满足值说成 0，与通常布尔值约定及式 (20.3)、(20.4) 将全 $x_i = J_{ai}$ 作为被排

[1] 译注：源前句“以上消失”与 SAT/UNSAT 定义及下句方向相反，此处保留并指出。

除的赋值存在冲突。这里保留原警告分量与文字，不无声交换 0、1；后面 S,U 的操作性“满足/违反”定义应与此源符号风险同时读取。

变量调查也按 J 重排：$J_{ai}=0$ 时 $(Q^S_{ia},Q^*_{ia},Q^U_{ia})=(Q_{ia}(0),Q_{ia}(*),Q_{ia}(1))$；为 1 时交换 0、1。它们分别是其他子句强迫 x_i 满足 a、不强迫、强迫违反 a 的概率；概率均指随机抽取纯态。

习题 20.3. *按前章程序，用 $Q^S,Q^U,Q^*,\widehat{Q}$ 显式写出 1RSB 方程。*

因子仅在所有其他变量均被强迫违反它时，才强迫目标变量，故

$$\widehat{Q}_{ai}=\prod_{j\in\partial a\setminus i}Q^U_{ja}. \tag{20.10}$$

变量节点中，令 $\Omega^S\subseteq S_{ia},\Omega^U\subseteq U_{ia}$ 为发强迫警告的子句；比较两集合大小，较多一侧决定满足/违反，等大不强迫；能量代价为 $\min(|\Omega^S|,|\Omega^U|)$，因此

$$Q^U_{ia}\cong\sum_{|\Omega^U|>|\Omega^S|}e^{-y|\Omega^S|}\prod_{b\in\Omega^U\cup\Omega^S}\widehat{Q}_{bi}\prod_{b\notin\Omega^U\cup\Omega^S}(1-\widehat{Q}_{bi}), \tag{20.11}$$

$$Q^S_{ia}\cong\sum_{|\Omega^S|>|\Omega^U|}e^{-y|\Omega^U|}\prod_{b\in\Omega^U\cup\Omega^S}\widehat{Q}_{bi}\prod_{b\notin\Omega^U\cup\Omega^S}(1-\widehat{Q}_{bi}), \tag{20.12}$$

$$Q^*_{ia}\cong\sum_{|\Omega^U|=|\Omega^S|}e^{-y|\Omega^U|}\prod_{b\in\Omega^U\cup\Omega^S}\widehat{Q}_{bi}\prod_{b\notin\Omega^U\cup\Omega^S}(1-\widehat{Q}_{bi}). \tag{20.13}$$

归一化使三者和为 1。可作更新映射或不动点条件。求和有 $2^{|\partial i|-1}$ 项，随机图平均度 $K\alpha$；临界附近 $\alpha=\Theta(2^K)$，项数达 $2^{\Theta(K2^K)}$，很快不可行，但可用卷积高效计算。

习题 20.4. *独立 Bernoulli 变量 X_b 均值为 η_b，$W_n(m)=\mathbb{P}(\sum_{b=1}^n X_b=m)$。*

(a) 证明 $W_n(m)=\eta_nW_{n-1}(m-1)+(1-\eta_n)W_{n-1}(m)$，由 $W_0(m)=\mathbb{I}(m=0)$ 可用 $O(n^2)$ 次运算求得全部 W_n。

(b) 如何用 $O(|\partial i|^2)$ 次运算计算上述 SP 右端？

20.2.2 自由熵 $F^{\mathrm{RSB},e}$

能量形式自由熵描述纯态的最小能量；源称这些纯态为不能由有界次数自旋翻转降低能量的亚稳极小值。给定 SP 准解，

$$F^{\mathrm{RSB},e}=\sum_{a\in C}F^{\mathrm{RSB},e}_a+\sum_{i\in V}F^{\mathrm{RSB},e}_i-\sum_{(ia)\in E}F^{\mathrm{RSB},e}_{ia}, \tag{20.14}$$

$$e^{F^{\mathrm{RSB},e}_{ia}}=1-(1-e^{-y})\widehat{Q}_{ai}Q^U_{ia}. \tag{20.15}$$

因子项 $e^{F^{\mathrm{RSB},e}_a}=1-(1-e^{-y})\prod_{i\in\partial a}Q^U_{ia}$，因为仅当全部入警告都指向错误方向时局域能量为 1。变量项中，$\Omega^S\subseteq\partial_0 i,\Omega^U\subseteq\partial_1 i$，有

$$e^{F^{\mathrm{RSB},e}_i}=\sum_{\Omega^U,\Omega^S}e^{-y\min(\Omega^S,\Omega^U)}\prod_{b\in\Omega^U\cup\Omega^S}\widehat{Q}_{bi}\prod_{b\notin\Omega^U\cup\Omega^S}(1-\widehat{Q}_{bi}). \tag{20.16}$$

译注：源指数将集合直接写入 min，应按前文计数解释为集合大小，原字形保留；子句集这里又记为 C，此前为因子集。

习题 20.5. *证明任意 $i\in\partial a$ 有 $F^{\mathrm{RSB},e}_{ia}=F^{\mathrm{RSB},e}_a$。*

20.2.3 大 y 极限：SP 方程

SAT 实例要描述和寻找满足赋值，可取 $y \to \infty$ 选择零能态。更新化为

$$\widehat{Q}_{ai} = \prod_{j \in \partial a \setminus i} Q^U_{ja}, \tag{20.17}$$

$$Q^U_{ja} \cong \prod_{b \in S_{ja}} (1 - \widehat{Q}_{bj}) \left[1 - \prod_{b \in U_{ja}} (1 - \widehat{Q}_{bj}) \right], \tag{20.18}$$

$$Q^S_{ja} \cong \prod_{b \in U_{ja}} (1 - \widehat{Q}_{bj}) \left[1 - \prod_{b \in S_{ja}} (1 - \widehat{Q}_{bj}) \right], \tag{20.19}$$

$$Q^*_{ja} \cong \prod_{b \in \partial j \setminus a} (1 - \widehat{Q}_{bj}), \tag{20.20}$$

三分量归一化。若各子句独立发警告，则第一乘积是不受满足方向警告的概率，第二括号是至少受一个违反方向警告的概率；Q^U 是条件于无矛盾后被迫违反的概率，其他分量类似。$\widehat{Q}$ 则为其余变量都被迫违反的概率。形式只比 BP 稍改，消息解释却完全不同。自由熵为

$$F^{\mathrm{RSB},e} = \sum_{a \in C} F^{\mathrm{RSB},e}_a + \sum_i F^{\mathrm{RSB},e}_i - \sum_{(ia)} F^{\mathrm{RSB},e}_{ia}, \tag{20.21}$$

$$F^{\mathrm{RSB},e}_{ia} = \log(1 - Q^U_{ia} \widehat{Q}_{ai}), \tag{20.22}$$

$$F^{\mathrm{RSB},e}_i = \log \left[\prod_{b \in \partial_0 i} (1 - \widehat{Q}_{bi}) + \prod_{b \in \partial_1 i} (1 - \widehat{Q}_{bi}) - \prod_{b \in \partial i} (1 - \widehat{Q}_{bi}) \right], \tag{20.23}$$

$$F^{\mathrm{RSB},e}_a = \log \left(1 - \prod_{j \in \partial a} Q^U_{ja} \right). \tag{20.24}$$

习题 20.6. *若消息满足 SP 不动点方程，证明自由熵可重写为* $F^{\mathrm{RSB},e} = \sum_i F^{\mathrm{RSB},e}_i + \sum_a (1 - |\partial a|) F^{\mathrm{RSB},e}_a$。

20.2.4 SAT–UNSAT 阈值

SP(y) 总有无警告不动点：各边 $\widehat{Q}_{ai} = 0$、$(Q^U, Q^S, Q^*) = (0, 0, 1)$。可通过大随机实例上迭代找其他点。腔方法将随机边消息升为随机变量，将更新读成依分布相等，用种群动力学研究；同样有 RS 无警告分布，有时还有非平凡分布。给定不动点，对自由熵各项按度和场取期望并除 N，得 $\mathcal{F}^e(y)$。无警告点上它为 0，表示 SAT 团簇数次指数、复杂度密度为零，粗略说低能解只有一团簇；注意能量方法计数团簇而非指数大的赋值数。

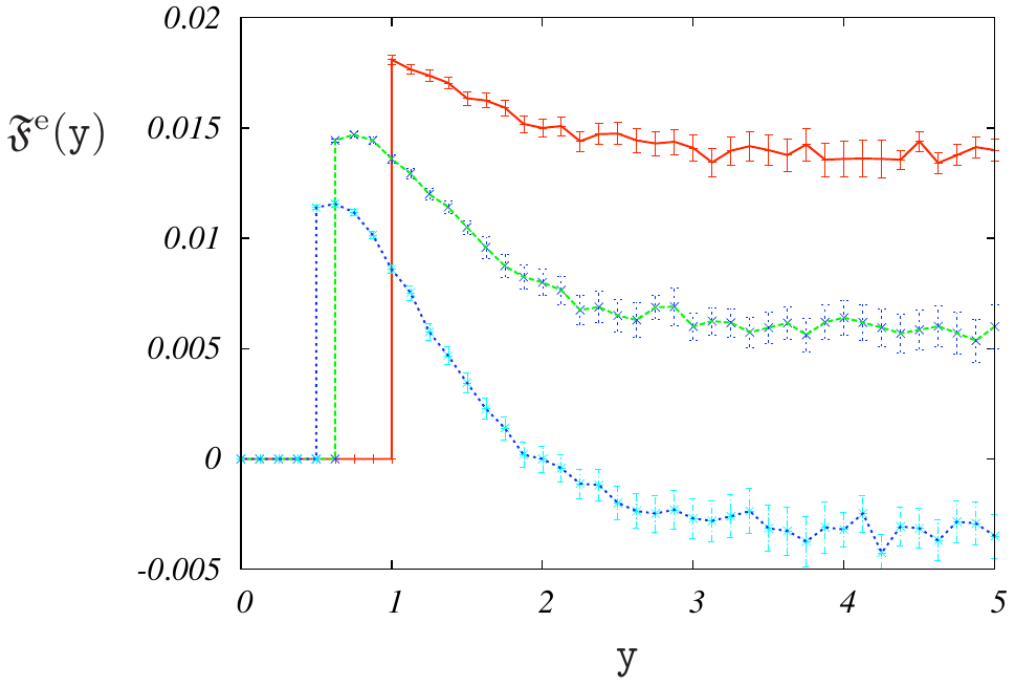


图 20.4: 3-SAT 的 1RSB 能量自由熵密度，$\alpha = 4.1, 4.2, 4.3$ 从上至下；每个 α, y 用 12000 个体迭代 $12 \cdot 10^6$ 次，并对末 $8 \cdot 10^6$ 次平均。

图 20.4 从 $[0,1]$ 均匀独立调查初始化。$\alpha < \alpha_{d,\mathrm{SP}} \simeq 3.93$ 时趋于无警告点；以上且 $y > y_d(\alpha)$ 时趋于非平凡点，自由熵非零。Legendre 变换得到 $\Sigma^e(\epsilon)$。实践中拟合 $\mathcal{F}^e_{\mathrm{fit}}(y) = \sum_{r=0}^{r_*} \psi_r e^{-ry}$、$r_* = 2$ 至 4，再变换拟合曲线。图 20.5 仅画所得复杂度的凹支[2]。

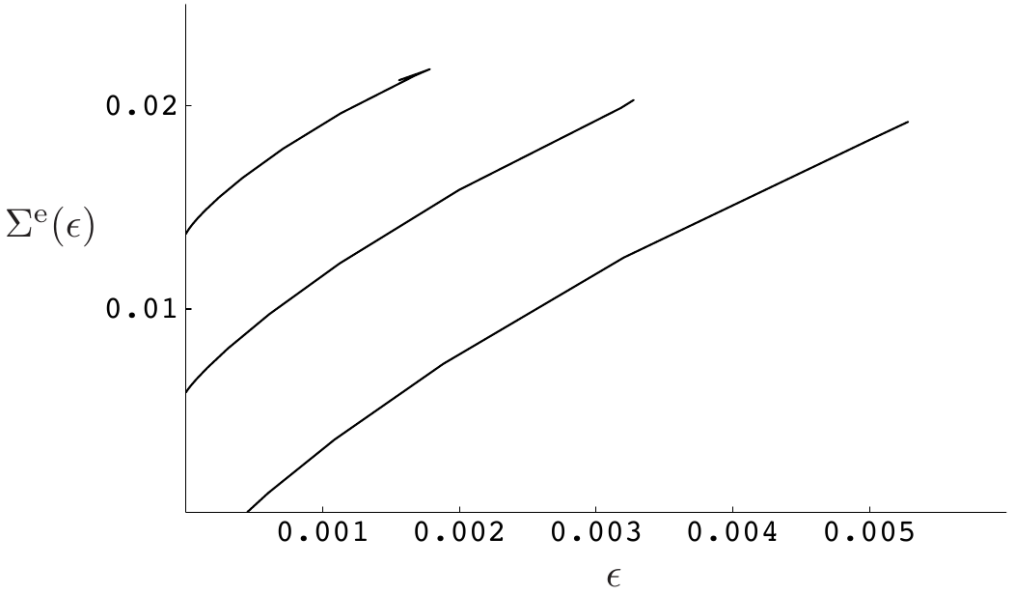


图 20.5: 3-SAT 能量复杂度对能量密度，$\alpha = 4.1, 4.2, 4.3$ 自上至下，由前图自由熵拟合的 Legendre 变换得到。

[2]复杂度另有凸支，在最大能量处接到凹支；其准确意义尚不明确。

习题 20.7. 证明 $\Sigma^e(0) = \lim_{y\to\infty} \mathcal{F}^e(y)$。

$\alpha = 4.1, 4.2$ 时零能复杂度为正，即零能密度最小和准解指数多。$\alpha = 4.3$ 时曲线从正能量开始，等价地形式上 $\Sigma^e(0) < 0$。典型解数不能指数下降，此结果被解释为典型随机公式没有零能密度最小和准解；按其与低能团簇的对应，便没有 SAT 赋值。

因此阈值在 4.2–4.3 间。更精确地画 $\mathcal{F}^e(\infty)$ 对 α，找零点，得到 $\alpha_s(3) = 4.26675 \pm 0.00015$。表 20.1 给其他 K。种群动力学可靠估计仅做到 $K \le 7$，因为阈值随 K 指数增长，给定精度所需种群也随之增大，平均输入数是 $K\alpha$。大 K 可形式展开，已算七项，前两项为

$$\alpha_s(K) = 2^K \log 2 - \frac{1}{2}(1 + \log 2) + O(2^{-K}K^2). \tag{20.25}$$

K	3	4	5	6	7	8	9	10
α_s	4.2667	9.931	21.117	43.37	87.79	176.5	354.0	708.9

表 20.1: 1RSB 腔方法对随机 K-SAT 的阈值预测。

20.2.5 SP 引导消元

如 BP，SP 提供的信息可作消元启发。先在给定实例上迭代 SP(y) 或其 $y = \infty$ 形式求近似解；下面取后者，以选择零能态。从独立同分布消息开始，例如平行更新，至满足收敛准则。图 20.6 用 $t_{\max} = 1000$、最大逐轮消息差 $\delta = 10^{-2}$，每边 $\widehat{Q}_{ai}$ 在 $[0,1]$ 独立均匀初始化。3-SAT 中 SP 比 BP 收敛好，甚至超过 SAT 阈值仍收敛。

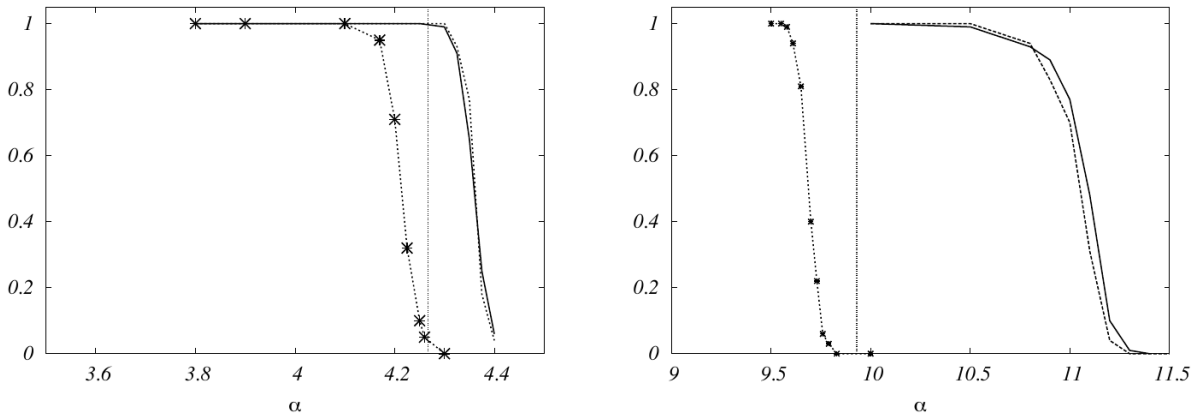


图 20.6: SP 收敛概率：左 3-SAT、右 4-SAT，100 实例；$N = 5 \cdot 10^3$ 实线、10^4 虚线。点是 100 个 $N = 5 \cdot 10^3$ 实例中 SP 消元成功率，竖线为预测 SAT 阈值。

数值提示两个阈值：$\alpha < \alpha_{d,\mathrm{SP}}$ 趋于平凡点；两阈值之间趋于非平凡点；$\alpha > \alpha_{u,\mathrm{SP}}$ 不收敛。均理解为大 N 下以高概率。中间区间预期有指数多个点，但多为退化的 “伪装 WP 点”，各调查仅 0 或 1；实际迭代到达的点对初值变化稳定，提示唯一非退化点。下阈值猜想与分布递推相同：3-SAT 约 3.93，4-SAT 约 8.30；上阈值分别约 4.36、9.7。

SP 收敛后计算各变量调查边缘

$$
\begin{aligned}
w_i(1) &\cong \prod_{a\in\partial_0 i}(1-\widehat{Q}_{ai})\left[1-\prod_{a\in\partial_1 i}(1-\widehat{Q}_{ai})\right],\\
w_i(0) &\cong \prod_{a\in\partial_1 i}(1-\widehat{Q}_{ai})\left[1-\prod_{a\in\partial_0 i}(1-\widehat{Q}_{ai})\right],\\
w_i(*) &\cong \prod_{a\in\partial i}(1-\widehat{Q}_{ai}), \qquad w_i(1)+w_i(0)+w_i(*)=1.
\end{aligned}
\tag{20.26}
$$

它们解释为条件于无矛盾时，变量被强迫为 1、0、不强迫的概率。定义 $\pi_i = w_i(0) - w_i(1)$，选绝对偏置最大者，按符号固定，继续消元。通常固定一定比例后约化实例 SP 趋于平凡点，按解释，此时仅一个 Bethe 测度，解不再成团簇；实践中简单算法也易求解，可接 BP 消元，或更简单的 WalkSAT、模拟退火。

SP 引导消元伪代码为：

1. 令 $U=\varnothing$，重复直到失败或 $U=V$。

2. 调用 $\mathrm{SP}(F,\varepsilon,t_{\max})$；不收敛则失败。对 $i\in V\setminus U$ 计算偏置，选绝对值最大者 j。

3. 若 $|\pi_j|\le 2^K\varepsilon$，调用 $\mathrm{WalkSAT}(F,f,p)$；否则按偏置符号固定 x_j，并以所得新公式替换 F。

4. 继续循环，最后返回当前赋值。

SP 过程为：初始化独立随机消息；对 $t=0,\dots,t_{\max}$，先更新全部 $\widehat{Q}_{ai}$，再按有限 y 公式更新原文所记 Q_{ai}，求与前轮最大差 Δ；若 $\Delta<\varepsilon$ 返回消息；循环结束返回 “不收敛”。WalkSAT 见第 10 章。**译注：** 源消元伪代码没有显式更新集合 U，也未写 WalkSAT 返回后的控制流；源 SP 过程引用有限 y 的式 (20.11)–(20.13)，而本段聚焦 $y=\infty$。均保留为源算法缺口，不将上述伪代码视为已验证可执行实现。式 (20.26) 的 0/1 解释也须结合前面警告约定风险读取。

经验上，3-SAT 在 $\alpha\lesssim 4.252$、4-SAT 在 $\alpha\lesssim 9.6$ 以高概率成功，略低于猜想阈值 4.2667、9.931。除 SP 子程序外，这个算法很朴素，可加入回溯释放已固定变量；也未利用额外成本很低的 $\mathcal{F}^e(\infty)$，可尝试选择最大化剩余团簇数对数的分支。

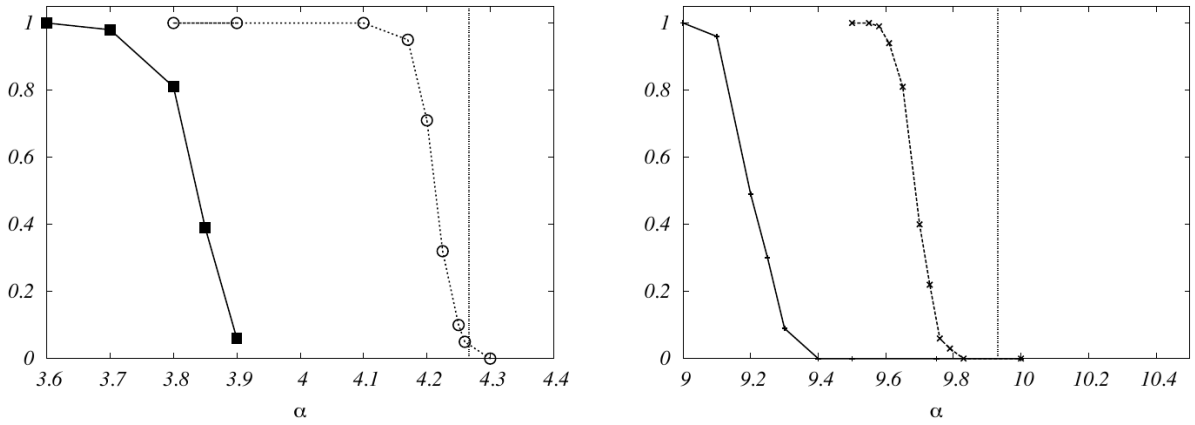


图 20.7: 3-SAT（左）、4-SAT（右）中 BP 与 SP 引导消元的成功概率，100 个 $N = 5 \cdot 10^3$ 实例平均；SP 点线优于 BP 实线，竖线为 SAT–UNSAT 阈值。

SP 消元明显优于 BP，原稿称它或小变体是当时临界附近大型随机公式的最有效方法。每轮 SP 需 $O(N)$，每次调用 $O(Nt_{\max})$，逐变量调用总计 $O(N^2 t_{\max})$。若固定一变量对消息影响很小，可每 $N\delta$ 步才调用一次，δ 为小常数，便降为 $O(Nt_{\max})$。收敛迭代数似乎随 N 很慢增长或不增，可把 $t_{\max}$ 想作大常数或 $O(\log N)$；这是经验判断。

为理解机制，可跟踪消元中复杂度曲线。源文说，SP 收敛后由零温自由熵再作 Legendre 变换得到曲线；[3]图 20.8 对 $N = 10^4, \alpha = 4.2$ 单实例每 1000 步绘一次。零能复杂度下降，表示团簇丢失；最多数亚稳团簇的 “阈值能量” 也下降[4]，真解较少被亚稳极小值掩盖。第二效应远强于第一；固定约半数变量后阈值能量消失，SP 平凡，剩余问题容易由 WalkSAT 解决。

[3]译注：仅有 $y = \infty$ 的单个值不足以恢复整条能量复杂度曲线，仍须有限 y 的自由熵信息；源简略措辞保留。

[4]高能 1RSB 解不稳定，故阈值能量不精确；预期真实行为定量上与 1RSB 接近。

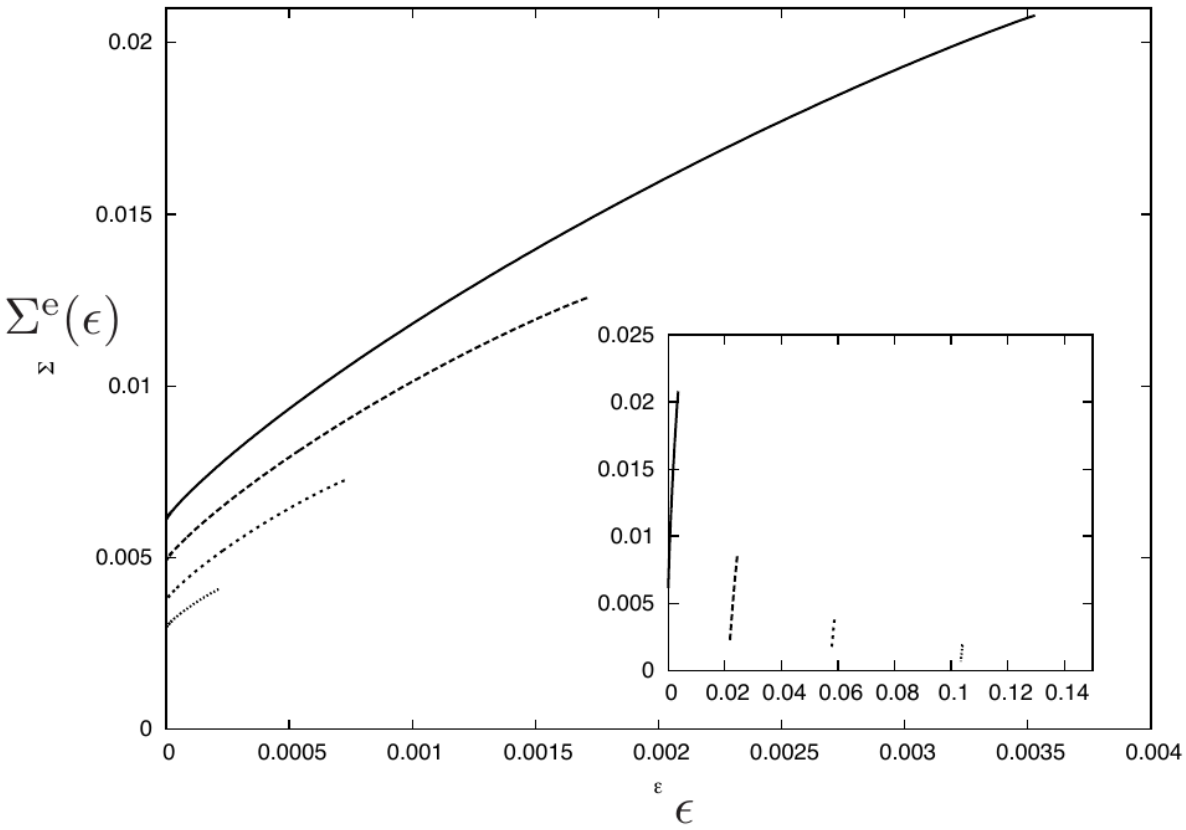


图 20.8: 单个 $N = 10000, \alpha = 4.2$ 随机 3-SAT 实例，原始及 SP 引导固定 1000、2000、3000 变量后（自上至下）的复杂度对能量密度。插图对比随机选择变量并任意固定值后的复杂度与总能量。

20.3 完整相图的几点认识

20.3.1 团簇熵

能量 1RSB 给出猜想精确的 SAT 阈值和有力 SP 算法，代价是忽略团簇大小、即内部熵。要精细理解 SAT 区解几何，须回到均匀解测度，用完整 1RSB 估计 $\mathcal{F}(x)$ 再作 Legendre 变换。$\Sigma(\varphi)$ 是自由熵 $N\varphi$ 的团簇数指数；只看 SAT 赋值时自由熵就是熵。

每个 BP 消息由 $[0,1]$ 实数参数化，1RSB 消息则是该区间的概率密度；每条有向边一个。研究相图还需对此类消息作统计分析，即大种群的分布函数，每个 x 都须迭代足够久估计自由熵，已接近当时数值能力极限。可辅以较简的两计算：SP 给 $x = 0$，以及 $x = 1$ 的特殊简化。

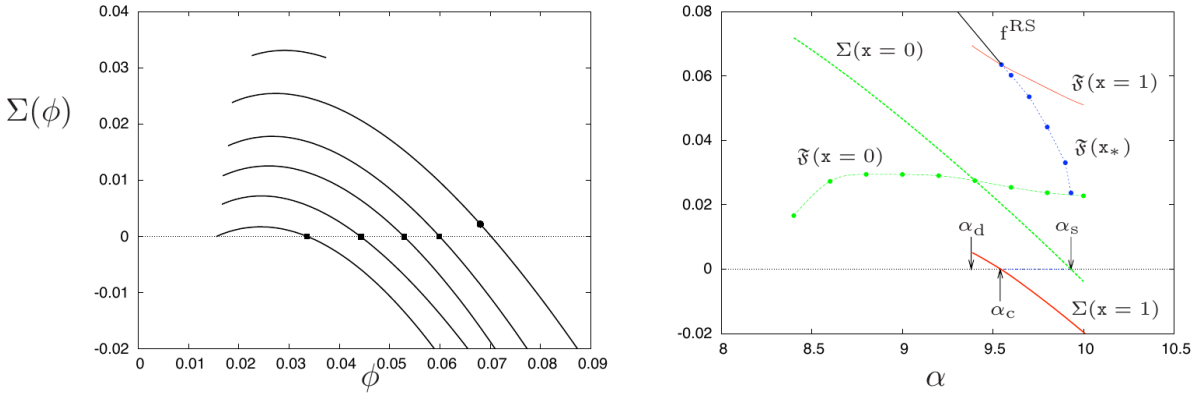


图 20.9: 4-SAT 的 1RSB 分析。左：$\alpha = 9.3, 9.45, 9.6, 9.7, 9.8, 9.9$ 自上而下的复杂度对内部熵密度；均匀采 SAT 解时，9.45 曲线的圆点（斜率 -1）代表指数多个团簇，$\alpha \geq 9.6$ 的方点代表少数态主导的凝聚。右：关键 x 下自由熵与复杂度；$x = 0$ 对应复杂度最大，$x = 1$ 对应斜率 -1，$x = x_*$ 对应复杂度零。阈值为 $\alpha_d \simeq 9.38, \alpha_c \simeq 9.547, \alpha_s \simeq 9.931$。

20.3.2 $K \geq 4$ 的凝聚转变

不列技术细节，用 4-SAT 说明完整转变图景：增大密度，先 RS ($\alpha < \alpha_d$)，再 d1RSB、有指数多个相关态 ($\alpha_d < \alpha < \alpha_c$)，再 s1RSB、测度凝聚于少数态 ($\alpha_c < \alpha < \alpha_s$)，最后 UNSAT。

增大密度类似一般图景中降温。给定密度，几乎所有团簇的内部熵为复杂度最大点 φ_0，$\Sigma(\varphi_0) = \mathcal{F}(0)$ 等于能量方法的零能复杂度。均匀抽 SAT 构型则几乎全部落在最大化 $\Sigma(\varphi) + \varphi$、且 $\Sigma \geq 0$ 的 φ_1 团簇中。d1RSB 中 $\Sigma(\varphi_1) > 0$，s1RSB 中为 0。可直接更精确地研究 $x = 1$，以 $\Sigma = 0, d\Sigma/d\varphi = -1$ 定位凝聚。

习题 20.8. 由 *Legendre* 关系证明凝聚点满足 $\mathcal{F}(1) - \mathcal{F}'(1) = 0$。$\mathcal{F}(1)$ 是 *RS* 自由熵，内部熵 $\mathcal{F}'(1)$ 也可由 $x = 1$ 形式显式求得；写出随机 *SAT* 的完整 $x = 1$ 方程并计算导数，是有意义的非平凡练习。

动力学点是 $x = 1$ 首次存在非平凡 1RSB 解的最小密度，实际最好通过第 22 章点到集关联研究。甚至低于 α_d 也可有 SAT 团簇：源文举 $\alpha = 4.3$，复杂度在 φ_0 附近有一支，但熵增大时未达到斜率 -1 就消失。解释是，仅指数小比例解分成远离团簇，绝大多数仍在单个良好连通的 RS 团簇。4-SAT 首次出现此类小团簇的密度是 $\alpha_{d,\mathrm{SP}} \simeq 8.3$。**译注：**这里 4-SAT 段落的源数值 4.3，与图 20.9 的 9.3 及本段 8.3 阈值不一致，原值保留。

$K = 5, 6$ 也发现同图景，预期对全部 $K \geq 4$ 成立。3-SAT 不同，$\alpha_c = \alpha_d$，其 1RSB 相总为凝聚。阈值见表 20.2。

K	α_d	α_c	α_s
3	3.86	3.86	4.2667
4	9.38	9.547	9.931
5	19.16	20.80	21.117
6	36.53	43.08	43.37

表 20.2: 随机 K-SAT 的动力学、凝聚和 SAT–UNSAT 阈值预测。源表注还列非平凡 SP 阈值，表中实际没有该列。

20.4 练习：随机图着色

图的正常 q-着色给每顶点赋 $\{1,\dots,q\}$ 中颜色，相邻顶点不同。随机图着色可沿 SAT 途径研究，有非常相似的行为。本节可当作应用腔方法的长练习，聚焦技术较简单的随机正则图，许多结论不用数值解腔方程；鼓励补齐省略细节。令

$$E(x)=\sum_{(ij)\in E}\mathbb{I}(x_i=x_j), \tag{20.27}$$

$$\mu(x)=\frac{1}{Z}\mathbb{I}(E(x)=0)=\frac{1}{Z}\prod_{(ij)\in E}\mathbb{I}(x_i\neq x_j). \tag{20.28}$$

Z 为正常着色数；每顶点一个变量节点、每边一个因子节点，是成对图模型。设原图为度 c 的随机正则图，对应 $D_N(\Lambda,P)$，$\Lambda(x)=x^c, P(x)=x^2$。固定半径的随机顶点邻域以高概率是确定形状的正则树，即多数顶点邻域相同。

RS 中可消去因子消息，BP 为

$$\nu_{i\to j}(x)\cong\prod_{k\in\partial i\backslash j}[1-\nu_{k\to i}(x)]. \tag{20.29}$$

正则性允许所有边相同的消息，特别有均匀解 $\nu(x)=1/q$，其自由熵等于熵密度

$$f^{\mathrm{RS}}=\log q+\frac{c}{2}\log(1-1/q). \tag{20.30}$$

它也等于退火估计 $N^{-1}\log\mathbb{E}Z$，随 c 增大而降低，$c>c_{\mathrm{UB}}(q)=2\log q/\log[q/(q-1)]$ 时为负。Markov 不等式给出此区以高概率不可着色，RS 也必然错误。稳定性分析给自旋玻璃易感率在 $c\uparrow c_{\mathrm{st}}(q)=q^2-2q+2$ 发散；$q\geq 4$ 时稳定阈值大于退火上界。

为修正，采用能量 1RSB 的 $y\to\infty$、即零能 SP。$Q_{i\to j}(x)$ 是去掉边 (i,j) 后，随机 Bethe 态中 x_i 被迫取色 x 的概率；$Q_{i\to j}(*)$ 是不强迫概率。将目标边标 0，其余输入边标 $1,\dots,c-1$，有

$$Q_0(x)=\frac{\sum_{(x_1,\dots,x_{c-1})\in\mathcal{N}(x)}Q_1(r_1)Q_2(x_2)\cdots Q_{c-1}(x_{c-1})}{\sum_{(x_1,\dots,x_{c-1})\in\mathcal{D}}Q_1(r_1)Q_2(x_2)\cdots Q_{c-1}(x_{c-1})}. \tag{20.31}$$

$\mathcal{D}$ 是 $\{*,1,\dots,q\}^n$ 中所有存在一个颜色 z 不等于任何输入的多元组，表示警告无矛盾；$\mathcal{N}(x)\subseteq\mathcal{D}$ 还要求任意 $z\neq x$ 都在某个输入出现，即 x 为唯一相容颜色。$Q_0(*)$ 由归一化确定。**译注：**源式首个参数写为 r_1，而求和指标为 x_1；源集合指数写为未定义的 n，实际多元组长 $c-1$。原字形均保留。

正则图允许各边相同、颜色置换对称的解，以 $a \in [0, 1/q]$ 参数化：

$$Q(x) = a \quad (x = 1, \dots, q), \qquad Q(*) = 1 - qa, \tag{20.32}$$

$$a = \frac{\sum_{r=0}^{q-1} (-1)^r \binom{q-1}{r} [1-(r+1)a]^{c-1}}{\sum_{r=0}^{q-1} (-1)^r \binom{q}{r+1} [1-(r+1)a]^{c-1}}. \tag{20.33}$$

零能复杂度为 $\lim_{y\to\infty} \mathcal{F}^e(y)$，得到

$$\Sigma^e(0; c, q) = \log \left[\sum_{r=0}^{q-1} (-1)^r \binom{q}{r+1} [1-(r+1)a]^c \right] - \frac{c}{2} \log(1 - qa^2). \tag{20.34}$$

固定 q 增加 c，类似 SAT 增约束。$c \geq c_{d,\mathrm{SP}}(q)$ 出现一对 $a > 0$ 非平凡解；取最大解计算复杂度，它随 c 增大而降低，$c \geq c_s(q)$ 时负，因而 c_s 为 1RSB 预测的可着色/不可着色阈值。

q	$c_{\mathrm{d,SP}}$	c_{d}	c_{c}	c_{s}
3	5	5	6	6
4	9	9	10	10
5	13	14	14	15
6	17	18	19	20
10	36	39	43	44

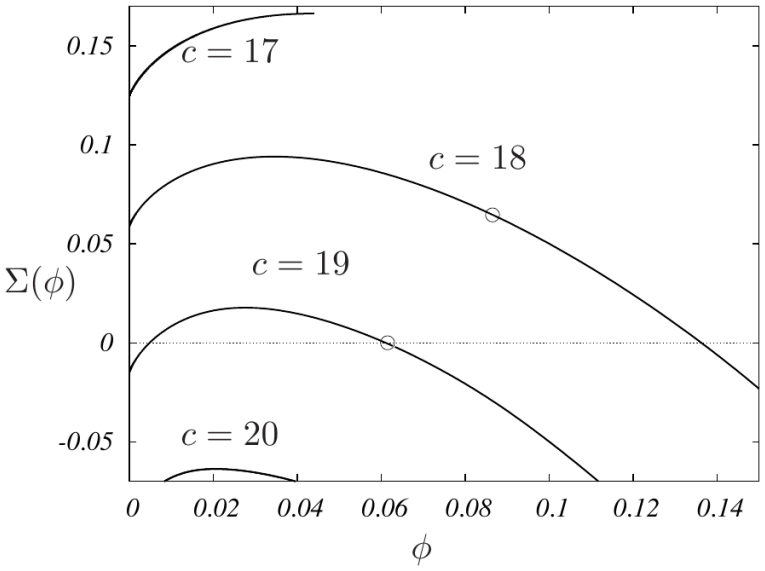


图 20.10: 随机正则图着色的 1RSB 结果。左表为非平凡 SP、动力学、凝聚和不可着色阈值；右为 $q = 6$ 的复杂度对团簇内部熵，$c = 17$ RS、18 d1RSB、19 s1RSB、20 不可着色。圆点为斜率 -1。

$c < c_s$ 可研究正常着色均匀测度及团簇熵，图 20.10 与 SAT 极相似。c_d 为 $x = 1$ 有非平凡 1RSB 解的最小度，c_c 为测度凝聚的最小度；图表列若干例。大 q 有

$$c_{d,\mathrm{SP}} = q(\log q + \log\log q + 1 - \log 2 + o(1)), \tag{20.35}$$

$$c_d = q(\log q + \log\log q + O(1)), \tag{20.36}$$

$$c_c = 2q\log q - \log q - 2\log 2 + o(1), \tag{20.37}$$

$$c_s = 2q\log q - \log q - 1 + o(1). \tag{20.38}$$

这些预测可改述为最少所需颜色数、即色数的猜想。

猜想 20.1. *N 顶点、度 $c \geq 4$ 的随机正则图，其色数以高概率等于*

$$\chi_{\mathrm{chrom}}(c) = \max\{q : \Sigma^e(0; c, q) > 0\}. \tag{20.39}$$

复杂度按式 (20.34)，其中 a 取式 (20.33) 在 $[0, 1/q]$ 的最大解。

原文据图表预测 $c=4,5$ 时色数 3，$c=6,7,8,9$ 时 4，$10\le c\le 14$ 时 5。**译注（源判据与例子的差异）：** 在 $c=4, q=3$ 时，式 (20.33) 化为 $a(1-6a+12a^2-6a^3)=0$；在 $[0,1/3]$ 上括号内量至少为 $1/9$，分母 $1-6a^3\ge 7/9$，故唯一允许解为 $a=0$。式 (20.34) 此时给出 $\Sigma^e(0;4,3)=0$，不满足式 (20.39) 的严格 $\Sigma^e>0$ 条件，与紧邻源例所称色数 3 不一致。这里保留原式的 max、严格不等号与原例；作者拟如何修正不可知。

严格结果方面，一二阶矩的巧妙应用给出：

定理 20.2. *令 k 是使 $c<2k\log k$ 的最小整数，则随机 c-正则图色数以高概率为 $k,k+1,k+2$ 之一；若还有 $c>(2k-1)\log k$，则以高概率为 $k,k+1$ 之一。*

可显式检验 1RSB 猜想与定理一致；定理给出大 c 的正确领先行为。本节聚焦正则图，但广泛图系综可同样分析。

注释

随机 SAT 的 RS 腔分析始于 Monasson 和 Zecchina（1996；1996），所得等价于 BP 密度演化。Pumphrey（2001）用 BP 找 SAT 解，认为它无效，主要因为一次性固定变量、没有采用逐次消元。

1RSB 用于随机 SAT 见 Mézard、Parisi 和 Zecchina（2003）、Mézard 和 Zecchina（2002），源文称其中计算 3-SAT 的 α_c。Mertens、Mézard 和 Zecchina（2006）推广至大 K 并求渐近。SPY、SP 及调查引导消元首先见 Mézard 和 Zecchina（2002），图 20.8 借自该文。Braunstein、Mézard 和 Zecchina（2005）提供算法化介绍，另有优化源码（同作者，2004）。Parisi（2003）提出回溯，但原稿称性能尚未系统研究。**译注：** 源重复同一 1996 引文、此处 α_c 与本章主要 SAT 阈值 α_s 的记号差异均保留。

凝聚现象见 Krzakala、Montanari、Ricci-Tersenghi、Semerjian 和 Zdeborova（2007），与着色熵复杂度（Mézard、Palassini 和 Rivoire，2005b；Krzakala 和 Zdeborova，2007）及 SAT（Montanari、Ricci-Tersenghi 和 Semerjian，2008）研究相关。

全章是待严格证明的启发式分析。但其中一项已对 $K\ge 8$ 严格建立：阈值以下某密度范围，SAT 赋值分成指数多个相互远离团簇（Mézard、Mora 和 Zecchina，2005a；Achlioptas 和 Ricci-Tersenghi，2006；Daudé、Mézard、Mora 和 Zecchina，2008）。可研究 x-可满足性：是否有相差 xN 个变量的两 SAT 赋值，以一二阶矩界阈值。

着色的能量 1RSB 始于 Mulet、Pagnani、Weigt 和 Zecchina（2002）及 Braunstein、Mulet、Pagnani、Weigt 和 Zecchina（2003），含阈值与 SP 推导。Krzakala 和 Zdeborova（2007）详细研究团簇熵及其他阈值，也研究 Erdős–Rényi 图。定理 20.2 由 Achlioptas 和 Moore（2004）证明，其 Erdős–Rényi 对应结果见 Achlioptas 和 Naor（2005）。

第二十一章　编码理论中的玻璃态

第 15 章随机 LDPC 解码有两个大码长转变。以交叉概率 p 的 BSC 为例，BP 比特错误率在 $p < p_d$ 时消失，以上严格正；同一系综符号 MAP 的最优比特错误率则在更大的 p_c 以下消失，以上与 0 有正间隔。

不同算法原则上有不同阈值，似乎不应太重视 p_d。但本章将说明，p_d 在一定意义上是系综的普适特征：以上有指数多个亚稳 Bethe 态，转变不仅是算法性的，也是结构性的动力学 1RSB 玻璃转变，提示它可能是广泛局域解码算法的最高阈值。两阈值都可形式地由 RS 密度演化不动点计算，本章从玻璃转变解释这一联系。

第 21.1 节数值研究亚稳态的作用，第 21.2 节用能量 1RSB 分析较简单的 BEC，第 21.3 节推广至一般无记忆信道，最后第 21.4 节联系常被视为解码失败原因的陷阱子图。

21.1　局域搜索与亚稳态

LDPC 码字是模 2 线性奇偶校验系统的解，类似 XORSAT，但系综不同。关键区别是寻找特定的发送码字，接收字 y 提供位置线索。设离散输出的 BMS 转移概率为 $\mathcal{Q}(y \mid x)$[1]，后验为

$$\mu_y(x) \cong \prod_{i=1}^{N} \mathcal{Q}(y_i \mid x_i) \prod_{a=1}^{M} \mathbb{I}(x_{i_1^a} \oplus \cdots \oplus x_{i_{k(a)}^a} = 0). \tag{21.1}$$

定义能量 $E(x)$ 为被违反校验数的两倍，码字恰为零能全局极小值。符号 MAP 计算后验边缘，码块 MAP 找后验最大点。下面讨论在接收字及信道限定的构型子集中优化能量，以及从相应倾斜 Boltzmann 分布采样。

21.1.1　受约束优化解码

给定接收字，任意 x（不必为码字）的信道输入对数似然为

$$L_y(x) = \sum_{i=1}^{N} \log \mathcal{Q}(y_i \mid x_i). \tag{21.2}$$

可无损假设发送全零。由大数定律，其似然接近 $-Nh$，$h = -\sum_y \mathcal{Q}(y \mid 0) \log \mathcal{Q}(y \mid 0)$；$O(N)$ 偏离的概率随 N 指数小。源文随后说寻找 L_y “接近 h” 的码字。[2]

[1] 源文在本章采用不同于其余章节的信道转移概率字形，以免与 1RSB 消息混淆；这里用 $\mathcal{Q}$ 区分。

[2] 译注：这里原句缺前述 $-N$ 因子，保留措辞并以其下一段明确的条件为准。

典型对解码如下：找满足“距离约束” $L_y(x) \ge -N(h+\delta)$ 的码字；恰有一个则返回，无或多个则报错。BSC 时它限制与接收字的 Hamming 距离。参数 $\delta > 0$ 应在 $N \to \infty$ 后趋于 0。

习题 21.1. 用线性结构和 *BMS* 对称性，证明典型对解码的码块错误率不依赖发送码字。

习题 21.2. 说明典型对解码与最大似然（*ML*）基本等价。

(a) 证明不存在 $L_y(x) \in [-N(h+\delta), -N(h-\delta)]$ 的码字的概率指数小。提示：对接收字类型用 *Sanov* 定理。

(b) 用如下事件的概率上界 *ML* 成功但典型对失败的概率：存在错误码字满足较宽似然条件，却没有错误码字满足较窄条件。

(c) 对 *Shannon* 随机码系综估计最后概率，证明严格低于 *MAP* 阈值、δ 足够小时它指数小。

因此典型对解码可写为

$$\text{最小化} E(x), \qquad \text{约束} L_y(x) \ge -N(h+\delta). \tag{21.3}$$

除指数稀有事件外，发送码字给一个零代价解；典型对成功当且仅当最小值非简并。$p < p_c$ 时以高概率如此，以上另有错误码字的零能极小值，且有指数多个似然不低于发送字的码字。

通常中间区 $p_d < p < p_c$ 有指数多个深亚稳极小值，发送码字仍是全局最小，却被它们掩盖；其出现阈值恰与 BP 阈值相同。MAP 仍能成功，消息传递却失败，原稿称当时没有已知实际算法能成功处理此区，见图 21.1。找任意零能构型虽可 Gauss 消元，但距离约束并非模 2 线性，故局域搜索会被亚稳态阻挡。

21.1.2 Δ 局域搜索解码

从满足似然条件的 $x(0)$ 出发，反复在半径 Δ 的邻域优化：

1. 找 $L_y(x(0)) \ge -N(h+\delta)$ 的初值。

2. 对 $t = 0, \dots, t_{\max}-1$，均匀随机选因子图中大小 Δ 的连通变量集 U；在 $j \notin U$ 固定 $x'_j = x_j$，求使能量最小的 x'。

3. 若 x' 满足似然约束，则取 $x(t+1) = x'$，否则保留 $x(t)$。

4. 返回 $x(t_{\max})$。

变量集连通指任两点可由路径相连，路径上的变量都在 U 内。

习题 21.3. 证明取 $x_i(0) = \arg\max_x \mathcal{Q}(y_i \mid x)$ 满足似然约束。



图 21.1: 受限构型空间的三种能量景观示意。左：发送码字是唯一零能全局极小值，无深局域极小值；中：全局仍唯一，但有许多深局域极小值；右：多个码字符合似然约束，零能极小值简并。源图注把空间写为 $L_y(x) \geq N(h-\delta)$，与正文的 $-N(h+\delta)$ 不同，且图注以违反数称 E、正文定义为其两倍；保留并标出。

有界度、固定 Δ 时每轮运算有界，取 $t_{\max} = O(N)$ 是线性复杂度。更重的贪心变体遍历所有候选 U，选最大能量降幅。能量单调不增，若达到 0 则实施了典型对解码；希望刻画以高概率达零的噪声与码系综。

$\Delta = 1$ 是第 11 章 BSC 比特翻转，有阈值 p_1 以下以高概率返回发送码字，合理预期以上失败。每个 Δ 都可定义 p_Δ，解析计算非常困难。可先研究 Δ-稳定构型：对所有符合似然约束、与 x 距离至多 Δ 的 x'，都有 $E(x') \geq E(x)$。

习题 21.4. *证明若没有 Δ-稳定构型，贪心算法至多 M 步找到码字。*

译注：原题“没有稳定构型”按源保留；有限可行集上的全局最优点本身稳定，因而有意义的用途须排除正能稳定陷阱，而非字面排除全部稳定点。此外算法只考察连通 U，与定义中任意距离至多 Δ 的扰动之间还需相应连接条件。亚稳态数本身不能确定 p_Δ；失败取决于有限时刻的构型分布是否主要落在这些吸引域中，困难正是刻画该分布。

21.1.3 模拟退火解码

更精细地分析第 13 章 MCMC：以 $\beta = 1/T$ 软化校验（不同于第 6 章乘在码字似然上的温度），定义

$$\mu_{y,\beta}(x) = \frac{1}{Z(\beta)} e^{-\beta E(x)} \prod_{i=1}^{N} \mathcal{Q}(y_i \mid x_i). \tag{21.4}$$

低温只支撑码字并按似然赋权；$\beta = 0$ 时比特独立，边缘为 $\mathcal{Q}(y_i \mid x_i)/[\mathcal{Q}(y_i \mid 0) + \mathcal{Q}(y_i \mid 1)]$，易采样。有限正 β 是软校验码输入分布，通常依赖具体校验矩阵，不只码本；实际算法也依赖这种表示，因此这是优点。

用 Glauber 采样。固定 β 解码在一定噪声以上失败，尝试逐步升 β 改进。源文先设 $\beta(0) = 0$，退火算法为：

1. 从 $\mu_{y,0}$ 生成 $x^*(0)$。
2. 对 $t = 0, \ldots, t_{\max} - 1$，置 $x(0;t) = x^*(t-1)$，在 $\beta(t)$ 作 n 次 Glauber 更新，得 $x(j;t)$、$j = 1, \ldots, n$，再置 $x^*(t) = x(n;t)$。

3. 返回 $x(t_{\max})$。

译注： 源循环从 0 开始却读取 $x^*(-1)$，返回量又未带星；这里保留这些边界记号，不将伪代码冒充可直接执行程序。总成本正比于 $nt_{\max}$，有效算法应随 N 线性或略超线性。直觉是高温先全空间平衡，再逐渐集中于码字附近，每阶段希望近似 $\mu_{y,\beta(t)}$。

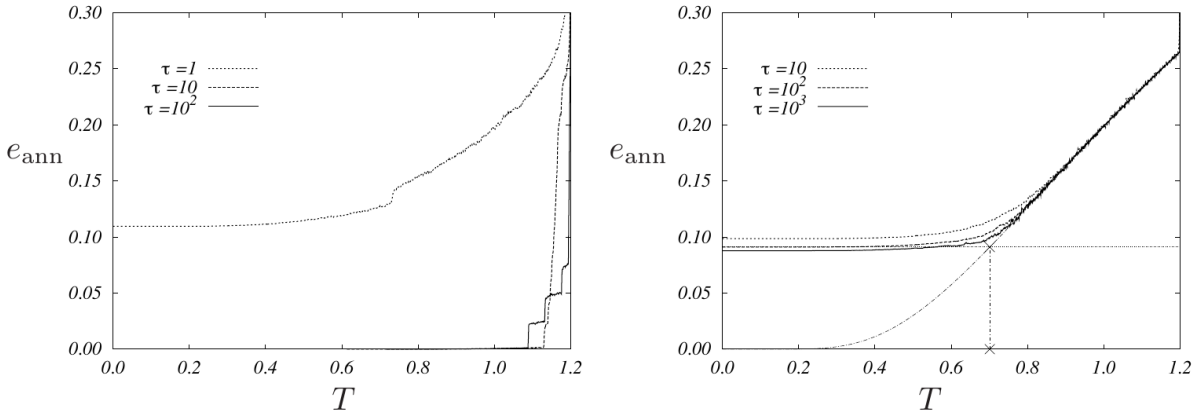


图 21.2: (5,6)LDPC、$N = 12000$、BSC 退火解码，左 $p = 0.12$、右 0.25。1200 个温度在 1.2 至 0 间等距，每温度 $n = N\tau$ 次更新；统计误差与曲线跳动大小相当。

该系综原文给 $p_d \simeq 0.139, p_c \simeq 0.264$。温度日程为

$$T(t) = T(0) - [T(0) - T(t_{\max})]\frac{t}{t_{\max}}, \tag{21.5}$$

$$\frac{1}{N}\langle E(x(t))\rangle \longrightarrow e_{\mathrm{ann}}(\beta(t)). \tag{21.6}$$

数值能量曲线对 10 次重复取平均，每次都重新随机抽取一个码。后式是每温度更新次数增大时的数值观察；大 N 时能量密度似乎也集中。

小 p 时，退火能量随 $\beta \to \infty$ 很快趋零，高效找到发送码字；$\beta = 1$ 已与零不可分辨。预期它在数值精度内等于平衡预测

$$e_{\mathrm{eq}}(\beta) \equiv \frac{1}{N}\lim_{N\to\infty}\langle E(x)\rangle_\beta. \tag{21.7}$$

最低激发为翻单比特、代价 10，故 $e_{\mathrm{eq}} = O(e^{-10\beta})$。大 p 则零温残余能量不消失，违反 $\Theta(N)$ 个校验；平衡零温能量必为零，故模拟已在有限 β 脱离平衡。低温能量变化极慢也支持这一点。下面将解释为在 $T_d = 1/\beta_d$ 动力学玻璃转变后陷入正能深极小值。

小噪声下，似然倾斜因子选择发送码字附近足够小、无亚稳态的区域，类似距离约束。退火在 $\beta \le \beta_d$ 仍平衡，故静态分析测度即可定位失衡起点。有限 β 下，有限系统 Glauber 若不可约、非周期，足够久总能平衡；这并非矛盾，因为先前隐含禁止更新数随 N 指数增长。可定义

$$e_{\mathrm{ann}}(\beta) \equiv \lim_{t_{\max}\to\infty}\lim_{N\to\infty}\frac{1}{N}\left\langle E_N\left(x\left(t_\beta = \lfloor(1-\beta(0)/\beta)t_{\max}\rfloor\right)\right)\right\rangle, \tag{21.8}$$

源设 $\beta(t_{\max}) = \infty$；关键是先 N 后日程时长，因而可能被亚稳态困住。**译注：** 式 (21.7) 的 $1/N$ 置于 $N \to \infty$ 极限外，照录，应按能量密度序列理解。式 (21.8) 若直接代入前面 $\beta(0) = 0$，t_β 对所有有限 β 都为终点；有限初温线性日程与最初无穷温初始化须另作一致约定，源式保留。

21.2 二元擦除信道

BEC 时可详细分析受约束优化亚稳态。发送全零，输出 $y\in\{0,*\}^N$，擦除集记 $U(y)$。源文写：非擦除位置均取 0 时 $L_y(x)=|U|\log\epsilon$，否则为 $-\infty$；发送码字属于前类。于是优化只需固定非擦除比特为 0，对剩余比特最小化违反校验数。**译注：**完整 BEC 似然还含 $(N-|U|)\log(1-\epsilon)$，它对这些可行字相同；忽略该常数不改变最优字，但应与前面完整似然阈值区分。端点 $\epsilon=0,1$ 用相应极限理解。

低于 MAP 阈值，唯一零能解是发送字，研究是否还有亚稳态。固定非擦除位后成为齐次 XORSAT，剩余变量度剖面仍为 Λ，校验度为 R，其中

$$R_k=\sum_{k'=k}^{k_{\max}}P_{k'}\binom{k'}{k}\epsilon^k(1-\epsilon)^{k'-k},\qquad r_k=\frac{kR_k}{\sum_p pR_p}. \tag{21.9}$$

习题 21.5. 证明 $r(u)=\sum_k r_k u^{k-1}=\rho(1-\epsilon(1-u))$。

假设能量 Ne 的最小和准解数为 $e^{N\Sigma^e(e)}$，以能量 1RSB 求复杂度。消息仍为 0、1、$*$ 的警告，调查为归一化三元组。

21.2.1 能量 1RSB 方程

变量到校验消息 $Q=(Q_0,Q_1,Q_*)$；反向为 $\widehat{Q}$。非擦除比特向各邻居发必然 0，所以

$$Q=\begin{cases}(1,0,0), & \text{概率}1-\epsilon,\\ \widetilde{Q}, & \text{概率}\epsilon.\end{cases} \tag{21.10}$$

习题 21.6. 证明分布满足

$$\widetilde{Q}_\sigma\overset{d}{=}F_{l,\sigma}(\widehat{Q}^1,\dots,\widehat{Q}^{l-1}), \tag{21.11}$$

$$\widehat{Q}_0\overset{d}{=}\frac12\prod_{i=1}^{k-1}(\widetilde{Q}_0^i+\widetilde{Q}_1^i)+\frac12\prod_{i=1}^{k-1}(\widetilde{Q}_0^i-\widetilde{Q}_1^i),$$

$$\widehat{Q}_1\overset{d}{=}\frac12\prod_{i=1}^{k-1}(\widetilde{Q}_0^i+\widetilde{Q}_1^i)-\frac12\prod_{i=1}^{k-1}(\widetilde{Q}_0^i-\widetilde{Q}_1^i),$$

$$\widehat{Q}_*\overset{d}{=}1-\prod_{i=1}^{k-1}(1-\widetilde{Q}_*^i), \tag{21.12}$$

$$F_{l,\sigma}(\{\widehat{Q}^a\})=\frac{Z_{l,\sigma}}{Z_{l,0}+Z_{l,1}+Z_{l,*}}, \tag{21.13}$$

$$Z_{l,\sigma}=\sum_{\Omega_0,\Omega_1,\Omega_*}^{(\sigma)}e^{-y\min(|\Omega_0|,|\Omega_1|)}\prod_{a\in\Omega_0}\widehat{Q}_0^a\prod_{a\in\Omega_1}\widehat{Q}_1^a\prod_{a\in\Omega_*}\widehat{Q}_*^a. \tag{21.14}$$

求和遍历 $[l-1]$ 的分割；$\sigma=0,*,1$ 分别要求 $|\Omega_0|>|\Omega_1|$、相等、小于。k,l 分别按 r_k,λ_l 抽取；源文字称 $\widetilde{Q}^i$ 为 $l-1$ 个副本、$\widehat{Q}^a$ 为 $k-1$ 个副本。

译注：上述副本数文字与公式乘积范围相反，保留。此节按单个违反约束计能量的 SP 权重 e^{-y}，而章首 E 是违反数两倍；使用同一个能量变量时须相应缩放 y 或能量密度，源没有在此明示

换算。辅助 Bethe 自由熵估计 $\mathcal{F}^e(y) = N^{-1}F^{\mathrm{RSB},e} = f^{\mathrm{RSB},e}$，再由 $\mathcal{F}^e(y) = \Sigma^e(e) - ye$ 作 Legendre 变换。

习题 21.7. 证明辅助模型 *Bethe* 自由熵为 $Nf^{\mathrm{RSB},e} + o(N)$，其中

$$f^{\mathrm{RSB},e} = -\Lambda'(1)\epsilon\,\mathbb{E}\log z_e(\widetilde{Q},\widehat{Q}) + \epsilon\,\mathbb{E}\log z_v(\{\widehat{Q}^a\};l) + \frac{\Lambda'(1)}{P'(1)}\mathbb{E}\log z_f(\{\widetilde{Q}^i\};k). \tag{21.15}$$

$$z_e = 1 + (e^{-y}-1)(\widetilde{Q}_0\widehat{Q}_1 + \widetilde{Q}_1\widehat{Q}_0), \tag{21.16}$$

$$z_v = \sum_{\Omega_0,\Omega_1,\Omega_*}\prod_{b\in\Omega_0}\widehat{Q}_0^b\prod_{b\in\Omega_1}\widehat{Q}_1^b\prod_{b\in\Omega_*}\widehat{Q}_*^b\,e^{-y\min(|\Omega_0|,|\Omega_1|)}, \tag{21.17}$$

$$z_f = 1 + \frac{1}{2}(e^{-y}-1)\left[\prod_{i=1}^{k}(\widetilde{Q}_0^i + \widetilde{Q}_1^i) - \prod_{i=1}^{k}(\widetilde{Q}_0^i - \widetilde{Q}_1^i)\right]. \tag{21.18}$$

期望对节点度 $l\sim\Lambda_l, k\sim R_k$ 及各独立输入取，变量项求和遍历 $[l]$ 的分割。

21.2.2 BP 阈值与亚稳性的出现

完整分布分析困难，但可用种群动力学。数值所得随 ϵ 有不同对称性；称 $\widetilde{Q}$ 或 $\widehat{Q}$ 对称，若 0、1 分量相等，称正，若 0 分量更大。BP 中边可分为最终为 0、最终仍擦除的两类，前类自然对应偏向 0 的正调查，后类对应对称调查。设随机调查 $b,\widehat{b}$ 对称、$c,\widehat{c}$ 正，作混合假设

$$\widetilde{Q} \overset{d}{=} \begin{cases} b, & \text{概率}\xi, \\ c, & \text{概率}1-\xi, \end{cases} \tag{21.19}$$

$$\widehat{Q} \overset{d}{=} \begin{cases} \widehat{b}, & \text{概率}\widehat{\xi}, \\ \widehat{c}, & \text{概率}1-\widehat{\xi}. \end{cases} \tag{21.20}$$

变量输出对称要求所有输入对称，因子输出对称只须至少一输入对称，得到相容条件

$$\xi = \lambda(\widehat{\xi}), \qquad\qquad \widehat{\xi} = 1-\rho(1-\epsilon\xi). \tag{21.21}$$

令 $z=\epsilon\xi, \widehat{z}=\widehat{\xi}$ 就是 BP 擦除密度演化不动点；ξ 对应 BP 后仍擦除的边比例。它将说明 BP 正确收敛停止的阈值与亚稳态出现相同。

$\epsilon\le\epsilon_d$ 时源称只有零解，且可取

$$\widehat{Q} = \widetilde{Q} = (1,0,0) \quad \text{几乎必然}. \tag{21.22}$$

场不跨态涨落，表示没有亚稳态；自由熵对所有 y 都为零。$\epsilon>\epsilon_d$ 仍有零解，又有正的非平凡解，BP 存在有限擦除比例不动点。数值迭代收敛到对称质量正的非平凡分布，Legendre 变换得图 21.3。**译注：**阈值处的唯一性及选择何个不动点按源措辞保留；临界切触时常有额外临界解，不能仅凭“以下”的分析自动纳入等号点。

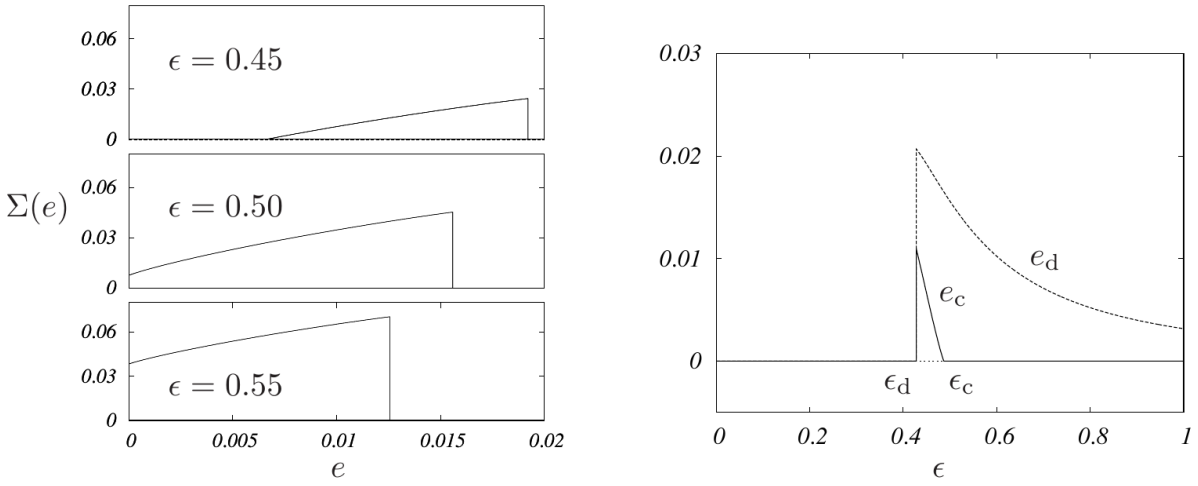


图 21.3: BEC 上的 (3,6) 系综，$\epsilon_d \simeq 0.4294, \epsilon_c \simeq 0.4882$。左：三个超过动力学阈值的擦除率下复杂度随能量密度；右：亚稳态最高、最低能量 e_d, e_c 随擦除率。

中间区仍有发送字零能解，由零混合解描述；非平凡解给在 (e_c, e_d) 内正复杂度，表示指数多个违反有限比例校验的亚稳态。噪声增大两能量下降；到 ϵ_c，e_c 连续为 0，此后 $e_c = 0, e_d > 0$，有指数多个零能态，即由 $\Theta(N)$ 能垒分开的码字。此时 $\Sigma(0) = f^{\rm RS}_{h,u}$，后者是第 15 章非平凡密度演化点的 RS 自由熵。

因此在同一框架内，BP 阈值为指数多个亚稳态出现点，具有结构、几何意义；MAP 阈值是最低亚稳能量消失点。退火数值图 21.4、21.5 也支持：阈值以下足够慢退火可线性时间找到码字，以上即使最慢日程也未找到，残余能量接近最高亚稳能量 e_d，提示陷在高处亚稳态。只预期粗略一致，残余能量还依赖完整动力学日程。

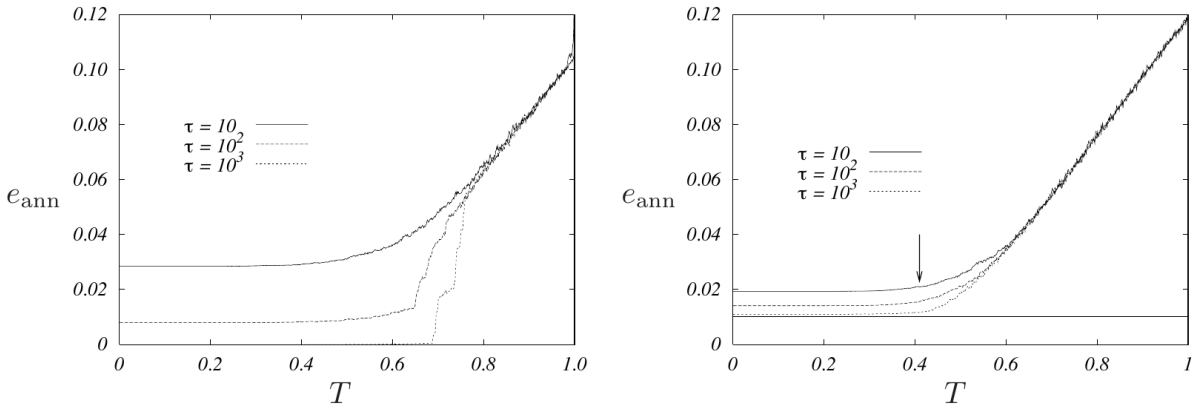


图 21.4: BEC 上的 (3,6) 码退火，$N = 10^4$，10^3 个等距温度从 1 至 0，每温度 $N\tau$ 次更新。左 $\epsilon = 0.4 < \epsilon_d$，右 0.6，水平线为 $e_d(0.6)$。

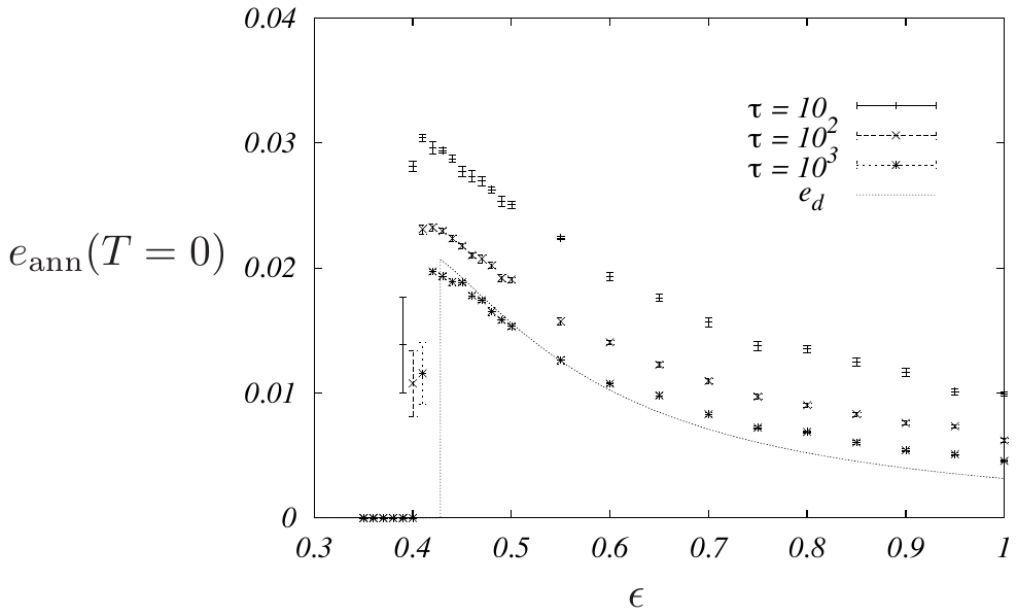


图 21.5: 同前图参数，零温退火残余能量对擦除率；实线为最高亚稳态能量。

21.3 一般二元无记忆对称信道

一般信道的似然距离条件不能写为局域二值约束，所以须用完整 1RSB，技术上比 BEC 复杂。这里不求完整复杂度，只判定倾斜测度随 β 增大是否发生动力学转变，并定位 $\beta_d(p)$。若有限逆温出现转变，测度分成指数多个纯态，退火跨过后陷入某态，继续降温的能量高于平衡且零温不消失。于是退火解码阈值是没有有限 β_d 的最大噪声。下面给一般方程和数值，再启发式说明 $p \downarrow p_d$ 时 $\beta_d \to \infty$。

21.3.1 1RSB 腔途径

对给定码与接收字研究式 (21.4)。有限温 BP 是第 15 章的推广，令

$$h_{i\to a} = \frac{1}{2}\log\frac{\nu_{i\to a}(0)}{\nu_{i\to a}(1)}, \qquad u_{a\to i} = \frac{1}{2}\log\frac{\widehat{\nu}_{a\to i}(0)}{\widehat{\nu}_{a\to i}(1)},$$

$$B_i = \frac{1}{2}\log\frac{\mathcal{Q}(y_i \mid 0)}{\mathcal{Q}(y_i \mid 1)} \equiv B(y_i). \tag{21.23}$$

$$h_{i\to a} = B_i + \sum_{b\in\partial i\setminus a} u_{b\to i} \equiv f_i(\{u_{b\to i}\}), \tag{21.24}$$

$$u_{a\to i} = \operatorname{atanh}\left[\tanh\beta \prod_{j\in\partial a\setminus i} \tanh h_{j\to a}\right] \equiv \widehat{f}_a(\{h_{j\to a}\}). \tag{21.25}$$

此处自由熵采用自然对数，不同于第 15 章：

$$
\begin{aligned}
F(u,h) = &- \sum_{(ia)\in E} \log\left[\sum_{x_i} \widehat{\nu}_{u_{a\to i}}(x_i)\nu_{h_{i\to a}}(x_i)\right] \\
&+ \sum_{i=1}^{N} \log\left[\sum_{x_i} \mathcal{Q}(y_i \mid x_i) \prod_{a\in\partial i} \widehat{\nu}_{u_{a\to i}}(x_i)\right] \\
&+ \sum_{a=1}^{M} \log\left[\sum_{x_{\partial a}} e^{-\beta E_a(x_{\partial a})} \prod_{i\in\partial a} \nu_{h_{i\to a}}(x_i)\right], \qquad (21.26)
\end{aligned}
$$

$$
\varphi = \frac{1}{N}F(u,h) - \sum_{y} \mathcal{Q}(y \mid 0)\log \mathcal{Q}(y \mid 0). \qquad (21.27)
$$

与前章相同，1RSB 假定移位自由熵密度为 φ 的 Bethe 态数，领先指数阶等于 BP 准解数，$\mathcal{N}(\varphi) \doteq e^{N\Sigma(\varphi)}$。辅助模型以 $e^{Nx\varphi}$ 赋权，$\mathcal{F}(x) = \lim_N F^{\mathrm{RSB}}(x)/N = x\varphi + \Sigma(\varphi)$，$\partial\Sigma/\partial\varphi = -x$。场分布满足

$$
Q_{ia}(h_{i\to a}) \cong \int \delta(h_{i\to a} = f_i(\{u_{b\to i}\}))\, z_{ia}^{x} \prod_{b\in\partial i\setminus a} d\widehat{Q}_{bi}(u_{b\to i}), \qquad (21.28)
$$

$$
\widehat{Q}_{ai}(u_{a\to i}) \cong \int \delta(u_{a\to i} = \widehat{f}_a(\{h_{j\to a}\}))\, \widehat{z}_{ai}^{x} \prod_{j\in\partial a\setminus i} dQ_{ja}(h_{j\to a}). \qquad (21.29)
$$

习题 21.8. 证明重加权因子为

$$
z_{ia}(\{u_{b\to i}\}, B_i) = \frac{2\cosh(B_i + \sum_{b\in\partial i\setminus a} u_{b\to i})}{\prod_{b\in\partial i\setminus a} 2\cosh u_{b\to i}}, \qquad (21.30)
$$

$$
\widehat{z}_{ai}(\{h_{j\to a}\}) = 1 + e^{-2\beta}. \qquad (21.31)
$$

带帽因子虽可吸收入归一化，仍显式保留。随机边上 $Q, \widehat{Q}$ 又成为随机分布，满足

$$
Q(h) \overset{d}{=} \frac{1}{Z}\int z(\{u_a\}; B(y))^{x}\delta[h - f_{l-1}(\{u_a\}; B(y))] \prod_{a=1}^{l-1} d\widehat{Q}_a(u_a), \qquad (21.32)
$$

$$
\widehat{Q}(u) \overset{d}{=} \frac{1}{\widehat{Z}}\int \widehat{z}(\{h_i\})^{x}\delta[u - \widehat{f}_{k-1}(\{h_i\})] \prod_{i=1}^{k-1} dQ_i(h_i). \qquad (21.33)
$$

$l \sim \lambda, k \sim \rho, y \sim \mathcal{Q}(\cdot \mid 0)$，输入是对应独立副本。$\widehat{f}_{k-1} = \operatorname{atanh}[\tanh\beta \prod_i \tanh h_i]$；源文这里将 f_{l-1} 写为 $B - \sum_a u_a$。**译注：** 后一减号与式 (21.24) 的加号冲突，原文字形保留，未静默改源。

1RSB 自由熵密度估计为

$$
\begin{aligned}
f^{\mathrm{RSB}}(Q,\widehat{Q}) = &-\Lambda'(1)\mathbb{E}\log z_e(Q,\widehat{Q}) + \mathbb{E}\log z_v(\{\widehat{Q}_a\}; l, y) \\
&+ \frac{\Lambda'(1)}{P'(1)}\mathbb{E}\log z_f(\{Q_i\}; k).
\end{aligned}
$$

期望按节点度 $k \sim P, l \sim \Lambda, y \sim \mathcal{Q}(\cdot \mid 0)$ 及独立消息取；源文字在此把 k 个带帽副本、l 个不带

帽副本对调。局域量为

$$z_e = \int dQ(h)d\widehat{Q}(u)\left[\sum_{x=0}^{1}\nu_h(x)\nu_u(x)\right]^x, \tag{21.34}$$

$$z_v = \int \prod_{a=1}^{l} d\widehat{Q}_a(u_a)\left[\sum_{x=0}^{1}\frac{\mathcal{Q}(y\mid x)}{\mathcal{Q}(y\mid 0)}\prod_{a=1}^{l}\nu_{u_a}(x)\right]^x, \tag{21.35}$$

$$z_f = \int \prod_{i=1}^{l} dQ_i(h_i)\left\{\sum_{x_1,\ldots,x_k}\prod_{i=1}^{k}\nu_{h_i}(x_i) \times\left[\mathbb{I}\left(\sum_i x_i \text{ 为偶数}\right)+e^{-2\beta}\mathbb{I}\left(\sum_i x_i \text{ 为奇数}\right)\right]\right\}^x. \tag{21.36}$$

译注： 源最后一式积分副本上限为 l，内部乘积却为 k，照录，应核对为同一因子度。此处 x 既作 Parisi 指数又作求和字母，按源保留；解释时须区分。自由熵含大量信息，适当 $\beta\to\infty$ 可得能量复杂度。这里不完整求解，只检测动力学转变。

21.3.2 动力学相变

$\beta_d(p)$ 是 $x=1$ 分布方程首次有非平凡解的最小 β；以上分解成指数多个纯态，预期退火跨过时脱离平衡。图 21.6 对 (5,6)BSC：小 p 未发现任何正温转变，大 p 则有有限 β_d，随噪声增大下降，构成遍历/非遍历相界。其出现噪声与原文此处给的 $p_d\simeq 0.145$ 数值上不可分辨。

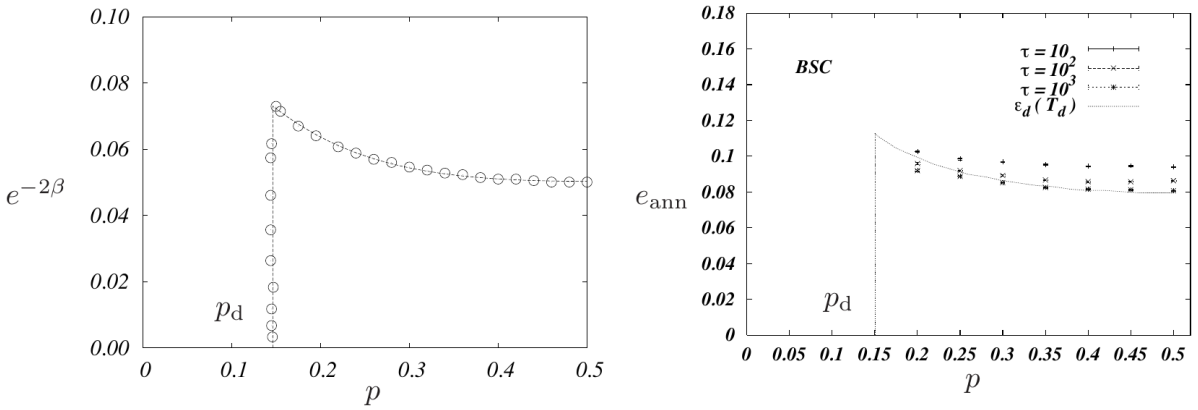


图 21.6: (5,6)BSC。左：动力学相界，圆点为采样密度演化、虚线引导视线。右：退火残余能量；虚线为转变温度 T_d 的平衡能量。

译注： 本段 0.145 与前面同系综的 0.139 不同，各自保留。原图左纵轴标 $e^{-2\beta}$，并非直接温度。

超过 p_d，退火残余能量正且对速率仅缓慢变化；与转变处平衡能量比较，后者相当于假设失衡后不再降能，虽不应严格成立，却是好的首估计。

21.3.3 亚稳态与 BP 阈值

对随 p 按物理退化排序的 BMS 族，零温亚稳 Bethe 态增殖点恰与 BP 阈值重合：下面论证 $\beta=\infty$ 时，$p<p_d$ 无非平凡 $x=1$ 解，$p>p_d$ 有解。预期多数信道族在依赖 p 的足够大有限 β 也如此，但原文说尚未证明。

度数 $l,k\geq 2$ 时，有发送字对应的无错解 $Q(h)=\delta_\infty(h)$、原文所写 $\widehat{Q}(u)=\delta_\infty(h)$，几乎必然，其移位自由熵为 0。$x=1$ 时平均普通消息满足 BP。低于阈值，前章只有无错 BP 解，因此不能有非平凡 1RSB 解，无玻璃相。高于阈值，密度演化有至少一个不同于无错的 RS 不动点，可构造非平凡 1RSB 解。

直觉是每个 Bethe 测度为孤立构型、即码字，局域边缘确定。寻找支撑于下列分布的解：

$$Q(h)=\tfrac{1}{2}(1+\tanh\widetilde{h})\delta_{+\infty}(h)+\tfrac{1}{2}(1-\tanh\widetilde{h})\delta_{-\infty}(h), \tag{21.37}$$

$$\widehat{Q}(u)=\tfrac{1}{2}(1+\tanh\widetilde{u})\delta_{+\infty}(u)+\tfrac{1}{2}(1+\tanh\widetilde{u})\delta_{-\infty}(u). \tag{21.38}$$

译注：源式 (21.38) 两权重均带加号，其和为 $1+\tanh\widetilde{u}$，一般不归一化；与上一式及概率分布定义不符。原式照录，不据此将后题视为无条件成立。前段带帽分布的 h/u 自变量错配也保留。

习题 21.9. *证明该假设解在 $\beta=\infty$ 满足 1RSB 方程，当且仅当*

$$\widetilde{h}\stackrel{d}{=}B(y)+\sum_{a=1}^{l-1}\widetilde{u},\qquad\qquad \widetilde{u}\stackrel{d}{=}\operatorname{atanh}\left[\prod_{i=1}^{k-1}\tanh\widetilde{h}_i\right]. \tag{21.39}$$

这些与 BP 密度演化不动点相同，所以高于 p_d，按 RS 不动点分布抽 $\widetilde{h},\widetilde{u}$，可得所述 1RSB 解，须同时记住源归一化疑点。

$\beta=\infty$ 的任意 $x>0$ 也类似，唯一变化是重加权使 $B(y)$ 换为 $xB(y)$，即对修改测度

$$\mu_y(x)\cong\prod_{a=1}^{M}\mathbb{I}(x_{i_1^a}\oplus\cdots\oplus x_{i_{k(a)}^a}=0)\prod_{i=1}^{N}\mathcal{Q}(y_i\mid x_i)^x \tag{21.40}$$

作 RS 计算。设修改问题有非平凡点，场分布为 $a_{\rm RS}^{(x)}$、$\widehat{a}_{\rm RS}^{(x)}$，相应 RS 自由熵为 $f^{\rm RS}(x)$，则原文给

$$\mathcal{F}(x)=f^{\rm RS}(x). \tag{21.41}$$

1RSB 复杂度计算化为稍改信道场的 RS 计算，但解释不同，必须恰当选 x 聚焦主导纯态。可用种群动力学，见图 21.7。

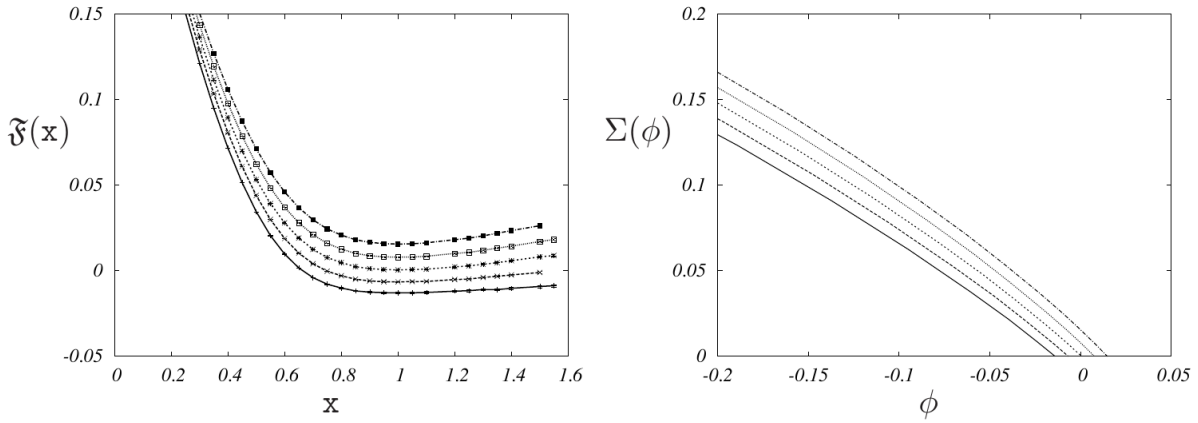


图 21.7: (3,6)BSC，$p_d\simeq 0.084, p_c\simeq 0.101$。左：辅助自由熵对 x，自下而上 $p=0.090,0.095,0.100,0.105,0.110$。右：复杂度对移位自由熵，同样噪声自左至右。

中间区有 $\varphi \le \varphi_0 < 0$ 的亚稳态带，低于无错态的 0，不主导测度，与 MAP 成功一致。源文称它们甚至“非物理”，因为 φ 是发送字给接收字后的条件熵密度，须非负；但解延续到有限 β 时描述非码字亚稳态，有清楚意义，解开这一疑问。超过 p_c，带上端正，玻璃态主导，MAP 失败。

21.4 亚稳态与近码字

BP 失败可归因于能量的深局域极小字，且在信道似然下权重显著。它们通常非码字，但从违反校验能量看很接近。可与有限码长错误平台的多种概念作定性联系。

低于 p_d，无限码长比特错误率消失，但不能无限增大 N：块编码延迟正比于 N，硬件实现也越困难，实际最大码长可能为 10^3 至 10^5。图 21.8 显示中等码长两区域：阈值附近错误率迅速下降的“瀑布区”，以及更低噪声的“错误平台”；平台低，但对图实例相对变化很大。

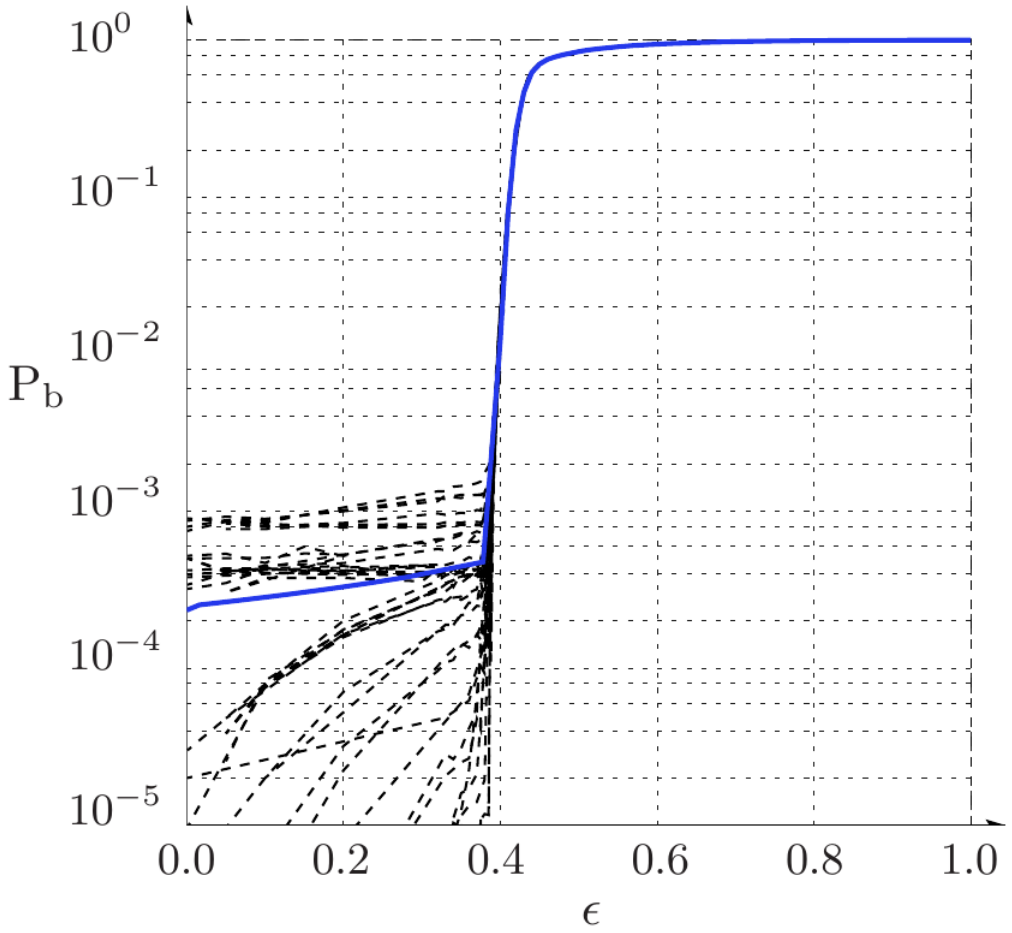


图 21.8: 40 个 $N = 2500$ 随机 (3,6) 码在 BEC 上的比特错误概率，实线为平均。

希望由给定图预测平台，除 BEC 外原稿称仍大体开放。许多启发式认为易出错的小 Tanner 子图导致平台。变量集 U 对应在 U 上为 1、外为 0 的构型，未必是码字，却某种意义接近码

字。识别子图类 $\mathcal{A}$ 后，若各类错误都稀有、不同子集错误近似独立，可估

$$P_B(G) \simeq \sum_{U \in \mathcal{A}} \mathbb{P}\{\text{BP 解码器在} U \text{ 失败}\}. \tag{21.42}$$

小 U 每项可用重要性采样有效计算。文献中各子图常以 (w, e) 表示危险性，小 w, e 更危险，实际仅求和小参数。

陷阱集（近码字）。包含 U 全部变量、相邻校验及相连边的子图；若 $|U| = w$、奇度校验数为 e，称 (w, e) 近码字。对应构型权重为 w、能量 $E(x) = 2e$；定义本身几乎无限制，可按信道或解码器加特别条件。

吸收集。源正文写作 Adsorbing sets；(w, e) 陷阱集另满足：每个变量邻接的子图内偶度校验多于奇度校验；且不含 $w' < w$ 的 (w', e) 吸收集。第一条件使对应构型对单比特翻转稳定，为能量局域极小值。小弱子图与错误率的联系仍有些模糊，能量景观或能提供弥合线索。

注释

本章主要基于 Montanari（2001b；2001a）及 Franz、Leone、Montanari 和 Ricci-Tersenghi（2002）的亚稳态分析。Migliorini 和 Saad（2006）也研究 1RSB，Neri、Skantzos 和 Bollé（2008）推广到非对称信道。这里典型对解码与 Aji、Jin、Khandekar、MacKay 和 McEliece（2001）原程序略不同。

Di、Proietti、Richardson、Telatar 和 Urbanke（2002）的停止集启发了许多平台研究。MacKay 和 Postol（2003）、Richardson（2003）首先令人信服地说明一般信道中的小子图平台机制。吸收集定义见 Dolecek、Zhang、Anantharam 和 Nikolić（2007），源 Notes 英文此处为 Absorbing，与正文 Adsorbing 不同。

模拟退火发明后，在运筹和概率领域研究甚多；综述见 Aarts、Korst 和 van Laarhoven（2003）。稀疏图模型的 1RSB 与退火实验详细比较见 Montanari 和 Ricci-Tersenghi（2004）。

第二十二章　仍在继续的故事

本书以统一视角讨论信息论、物理和计算机科学中的若干重要问题，给出一套相互协调的方法。但这一领域远未被充分理解，仍有许多挑战。本章综合描述其中一些问题，并概述近期进展，希望为这个新兴领域提出研究议程。大致有三条方向。

第一条也是主要挑战，是更好地定性理解稀疏随机图上的模型，见第 22.1 节。腔方法的核心假定是，这些系统只有少数几种行为，即相。每相对应一种复本对称性破缺模式：RS、1RSB 等；又可用纯态分解或长程关联描述。理解这些相具有普适性的根本原因和成立条件，以及不同刻画之间的等价性，将极为重要。

第二条涉及腔形式体系本身，见第 22.2 节。此前主要讨论预期 RS 或 1RSB 腔方法在大系统极限渐近精确的系统；这一预期部分基于 1RSB 的内部一致性检查，尤其是解对小扰动的稳定性。通过检查后，物理学家往往相信腔方法给出的阈值、单位变量最低代价等是精确猜想。若不通过，则认为需要更高阶 RSB；此时状况更不令人满意，连启发式计算也有技术困难。

第三条是玻璃相变与算法变慢之间的联系，见第 22.3 节。这对信息论与计算机科学应用尤其重要：正如信道编码中的 LDPC 码，稀疏图模型可用于许多实际任务。经验证据表明相变影响算法行为与效率。物理学家希望某种统一解释最终能把它联系到解集的几何结构和测度的关联性质。虽有一些支持这一观点的一般论证，实际理解仍很有限。

22.1　Gibbs 测度与长程关联

抽象地说，前几章的腔方法依赖一个尚未证明的结构定理。考虑离散空间 $\mathcal{X}^N$ 上的通用图模型

$$\mu(x) = \frac{1}{Z} \prod_{a \in F} \psi_a(x_{\partial a}). \tag{22.1}$$

腔方法假定：从适当系综取得的广泛模型，在大 N 极限由少数通用情景之一，即某个相，定性描述，再巧妙利用该相的定性特征作定量预测，例如相变位置。

毋庸说，我们既不能以这种一般性精确陈述，更不能证明这个结构定理；完整的必要假设也未知。但此前已见 XORSAT、稀释自旋玻璃和纠错码等例子。原则上因子图不必局部树状，不过实践中这类模型最容易控制。挖去一个空腔后，其边界变量彼此相距很远；大系统极限下它们的关联结构便较简单，从而可能写出渐近精确的递推。

这里不再细谈假设。即使只在较窄范围，如随机 K-SAT 解上的均匀测度，证明这种结构定理也是重要成果。我们着重说明腔方法假定的相的主要特征，尤其是两种互补刻画：

1. 将 $\mu(\cdot)$ 分解成团块或簇；下面精确定义这些团块，称为纯态。

2. 考察因子图上远隔变量的关联；将介绍两种差别细微、却对应不同相的关联衰减概念。

它们也分别联系腔方法的不同方面。

22.1.1 关于纯态的定义

纯态是严格统计力学的关键概念，但标准定义通常针对无限图上的平移不变模型。这里考虑的稀疏随机图还包括由标签规定函数节点性质的随机图，标准方法并不直接适用；我们需要对有限图有意义的具体定义。

考虑按变量节点数 N 编号的有限图模型序列 $\{\mu_N\}$。纯态分解为每个 N 指定构型空间的一个划分：

$$\mathcal{X}^N = \Omega_{1,N} \cup \cdots \cup \Omega_{\mathcal{N}_N,N}. \tag{22.2}$$

它必须满足：

1. 每个子集的测度与 1 有正间隔：

$$\max\{\mu_N(\Omega_{1,N}), \ldots, \mu_N(\Omega_{N,N})\} \le 1 - \delta. \tag{22.3}$$

2. 子集之间有瓶颈。对 $\Omega \subseteq \mathcal{X}^N$，定义其 ϵ 边界

$$\partial_\epsilon \Omega \equiv \{x \in \mathcal{X}^N : 1 \le d(x, \Omega) \le N\epsilon\}, \tag{22.4}$$

其中 $d(x, \Omega)$ 是 x 与 Ω 中构型的最小 Hamming 距离。要求对某个 $\epsilon > 0$，

$$\lim_{N\to\infty} \max_r \frac{\mu_N(\partial_\epsilon \Omega_{r,N})}{\mu_N(\Omega_{r,N})} = 0. \tag{22.5}$$

边界质量小，可能只是集合本身小，也可能是边界相对内部特别小；只有后者是真正的瓶颈，因此必须除以内部质量。

3. 限制在 $\Omega_{r,N}$ 内的条件测度

$$\mu_N^r(x) \equiv \frac{\mu_N(x)\mathbb{I}(x \in \Omega_{r,N})}{\mu_N(\Omega_{r,N})} \tag{22.6}$$

不能再按前两条分解。

译注： 原式 (22.3) 最后一个指标印为 N，而划分数为 $\mathcal{N}_N$；照录。比值及条件测度仅对正质量部分有定义，零质量集合应另作约定。给定划分，分布可写为支撑不交的分布的凸组合：

$$\mu_N(\cdot) = \sum_{r=1}^{\mathcal{N}_N} w_r \mu_N^r(\cdot), \qquad w_r \equiv \mu_N(\Omega_{r,N}). \tag{22.7}$$

分解不必唯一，因为可忽略质量的构型可分配给不同纯态；但条件测度应仅弱依赖划分的精确选取。

例 22.1. 考虑随机 $(k+1)$-正则图上的铁磁 *Ising* 模型，$x_i \in \{+1,-1\}$，

$$\mu_N(x) = \frac{1}{Z_N(\beta)} \exp\left\{ \beta \sum_{(i,j)\in E} x_i x_j \right\}. \tag{22.8}$$

为免无关细节，设 N 为奇数。依源书第 *17.3* 节讨论，预期 $k\tanh\beta > 1$ 时存在非平凡纯态划分 $\Omega_+ \cup \Omega_- = \mathcal{X}^N$；$\Omega_+$、$\Omega_-$ 分别由 $\sum_i x_i$ 正、负的构型组成，权重各为 $1/2$。对任意固定 C，改以 $\sum_i x_i \geq C$ 定义 Ω_+，便得渐近等价的分解。

条件 (22.5) 意味着相对 μ_N 满足细致平衡的局域 Markov 动力学会很慢。更确切地，若

$$\frac{\mu_N(\partial_\epsilon \Omega_{r,N})}{\mu_N(\Omega_{r,N})} \leq \exp\{-\Delta(N)\}, \tag{22.9}$$

则每步至多翻转 $N\epsilon$ 个变量且满足细致平衡的动力学，弛豫时间大于 $C\exp\{\Delta(N)\}$；C 与 N 无关、依模型细节而定。原文还称：从 $x \in \Omega_{r,N}$ 初始化后，到达距此集合 $N\epsilon$ 处需同阶时间。**译注：**瓶颈比值可控制平衡条件下或适当初始分布的逃逸行为；它本身不对集合内每个初始点给出同样的逐点逃逸时间下界，边界附近的特定初态需另作限定。

在随机因子图系综中，常预期 $\Delta(N)$ 线性增长。也可在纯态定义中直接要求这种界，取适当函数如 $\Delta(N) = N^{\psi}$。于是纯态在短于 $\exp\{\Delta(N)\}$ 的时间尺度上稳定。

22.1.2 关联衰减的概念

上述弛豫时间带来第二个核心概念：关联衰减。统计力学的一条重要经验是，仅有短程关联的系统应迅速弛豫到平衡。直观上，独立的粒子、自旋等自由度在单自由度的微观时间尺度内弛豫；若仅短程关联，可将其粗粒化为近乎独立的集体变量。大小 B 的原变量块有 $|\mathcal{X}|^B$ 种取值，在原 Boltzmann 分布下近乎独立。

在非 Euclid 图上必须明确何谓关联衰减。下面两个判据初看相似，实际并不相同，各自刻画不同的通用相。最简单的方法是用两点关联，并对位置平均形成磁化率。Ising 自旋的例子是

$$\chi_{\mathrm{SG}} = \frac{1}{N} \sum_{i,j\in V} \left(\langle x_i x_j \rangle - \langle x_i \rangle \langle x_j \rangle \right)^2. \tag{22.10}$$

括号表示对 μ 取平均。若它在 $N \to \infty$ 时有界，就提示短程关联。通过第 2.3 节涨落耗散关系，这对应局域微扰稳定性：在单点 i 施加扰动后，稳定性要求全局可观测量 $\sum_j f(x_j)$ 的变化有界；节点 j 边缘的变化正比于 $\langle x_i x_j\rangle - \langle x_i\rangle\langle x_j\rangle$。如第 12.3.2 节，不同 j 的项可能抵消，因而平均影响常消失，更确切地 $\lim_{N\to\infty} N^{-1}\sum_j (\langle x_i x_j\rangle - \langle x_i\rangle\langle x_j\rangle) = 0$。典型效应由自旋玻璃磁化率捕捉。

推广到一般字母表，只需度量联合分布与边缘乘积的差异，例如全变差距离：

$$\| \mu_{ij} - \mu_i \mu_j \| \equiv \frac{1}{2} \sum_{x_i, x_j} |\mu_{ij}(x_i, x_j) - \mu_i(x_i)\mu_j(x_j)|. \tag{22.11}$$

对顶点平均定义两点关联

$$\chi^{(2)} \equiv \frac{1}{N} \sum_{i,j\in V} \| \mu_{ij} - \mu_i \mu_j \|. \tag{22.12}$$

习题 22.1. 对 *Ising* 变量证明 $\chi_{\mathrm{SG}} = o(N)$ 当且仅当 $\chi^{(2)} = o(N)$。提示：令 $C_{ij} = \langle x_i x_j\rangle - \langle x_i\rangle\langle x_j\rangle$，证明 $C_{ij} = 2\|\mu_{ij} - \mu_i\mu_j\|$，再用 $\chi_{\mathrm{SG}} = N\mathbb{E}C_{ij}^2$、$\chi^{(2)} = N\mathbb{E}|C_{ij}|/2$，其中 i,j 在 V 中独立均匀抽取。

译注： 提示第一式左侧应取绝对值 $|C_{ij}|$；协方差可以为负。其后含绝对值的期望式与习题的等价结论不受这一漏号影响。类似地可定义 l 点关联：

$$\chi^{(l)} \equiv \frac{1}{N^{l-1}} \sum_{i(1),\dots,i(l)\in V} \|\mu_{i(1)\cdots i(l)} - \mu_{i(1)}\cdots\mu_{i(l)}\|. \tag{22.13}$$

其思想实验解释如下。给定 N 维分布 μ 及均匀随机节点 $i(1)$ 的边缘，要测试其对小扰动的稳定性。在另 $l-1$ 个随机节点施加扰动，使 $\mu'(x) \cong \mu(x)\prod_{a=2}^{l}[1+\delta_a(x_{i(a)})]$。在乘积 $\delta_2\cdots\delta_l$ 的一阶，$i(1)$ 边缘的变化在期望上由 $\chi^{(l)}$ 控制，也是涨落耗散关系的一种版本。

定义 22.2 (第一类关联衰减)**.** 若对每个有限 l，均有 $\chi^{(l)}/N \to 0$，则称图模型 μ 对小扰动稳定。

实践中，足够均匀的平均场模型里，这等价于仅取 $l=2$ 所得稳定性。

第二个判据考察 x_i 与全部远处变量的关联。固定整数 ℓ，以 $B(i,\ell)$ 为中心在 i、半径 ℓ 的球，$\overline{B}(i,\ell)$ 为其补集，即 $d(i,j)\ge\ell$ 的节点集。用联合分布与边缘乘积的全变差定义点到集合关联函数：

$$G_i(\ell) \equiv \|\mu_{i,\overline{B}(i,\ell)} - \mu_i\mu_{\overline{B}(i,\ell)}\|. \tag{22.14}$$

可作两种思想实验解释。第一种来自结构玻璃，用以说明脆性玻璃的长程关联：从 μ 抽一个参考构型 x^*，固定球外变量为参考值，球内变量则按给定球外的条件分布重抽为 x。若模型有某种刚性，x_i 应接近 x_i^*。原文称 $G_i(\ell)$ 衡量二者分布差多少。**译注：** 无条件重抽后 x_i 与 x_i^* 的单点边缘其实相同；此处应理解为球外信息引起的条件边缘变化或相关性，而非两个无条件单点分布之差。球及补集的端点约定也须与 $d\ge\ell$ 一致。

第二种解释带有统计学或计算机科学色彩：有人从 μ 抽 x^*，只告诉你远处的 x_j^*，要求尽力重构 x_i^*。在计算能力无限的假定下，G_i 衡量这些信息相对完全未知时能提高多少猜测能力。

定义 22.3 (第二类关联衰减)**.** 若对所有 i，$\ell\to\infty$ 时 $G_i(\ell)\to 0$，则称 μ 不可重构，或满足极端性条件。更精确地，要求存在 $\delta(\ell)\to 0$，使对一切 i,N 有 $G_i(\ell)\le\delta(\ell)$。相反，若大距离时该关联与 *0* 有正间隔，则称可重构。

22.1.3 通用情景

现在描述此前遇到的 RS、动力学 1RSB 和静态 1RSB 三相的纯态分解及关联衰减。在局部树状随机图上，各相也可用相应腔方法研究。这里排除需要精细调参的临界点，以及零场铁磁 Ising 等全局对称性造成的多重性。还有下一节的高阶 RSB 等其他通用相，甚至可能存在尚未探索的相。

复本对称相。 不存在式 (22.7) 的非平凡分解，即以高概率 $\mathcal{N}_N = 1$。两种判据下关联均衰减：对小扰动稳定且不可重构，具有最强意义的短程关联；第 14 章 RS 腔方法给出渐近精确预测。

动力学 1RSB 相。 存在指数多个纯态，以高概率 $\mathcal{N}_N = e^{N\Sigma+o(N)}$，$\Sigma > 0$。大部分测度由大小相近的态承载：任意 $\delta > 0$，除指数小的一部分外，质量都在满足

$$-\Sigma - \delta \le \frac{1}{N}\log \mu(\Omega_{r,N}) \le -\Sigma + \delta \tag{22.15}$$

的态内。它对小扰动稳定却可重构；有限个探针看不见长程关联，但点到集合关联存在，例如导致可逆 Markov 动力学变慢。由式 (12.31)，重叠分布 $P(q)$ 在此相平凡，但第 12.3.4 节的 ϵ 耦合方法可揭示其玻璃性。1RSB 腔方法可精确求解渐近自由能密度；热力学主导态对应 $x = 1$。

静态 1RSB 相。 这是真正类似 REM 低温相的 1RSB：纯态权重相差悬殊。原文写，对任意 $\delta > 1$，质量的 $1-\delta$ 部分由权重最大的 $k(N,\delta)$ 个纯态承载，且 $N \to \infty$ 时 k 收敛到有限整数值随机变量。降序权重 $w_{(1)} \ge w_{(2)} \ge \cdots$ 收敛到第 8 章的 Poisson–Dirichlet 过程。此相不对小扰动稳定，且可重构；两种意义都有长程关联。$P(q)$ 有两个 Dirac 峰，见图 12.3；1RSB 腔方法仍可精确求解。**译注：** 原条件 $\delta > 1$ 使 $1-\delta < 0$，不能表达质量集中；通常应在 $0 < \delta < 1$ 范围理解这一陈述，源条件照录。

三相广泛出现，常由相变分开：聚簇或动力学转变分隔 RS 与动力学 1RSB；凝聚转变分隔动力学与静态 1RSB。图 22.1 示意第 20.3 节的 $K \ge 4$ 随机 SAT：$\alpha < \alpha_d$ 为 RS，$\alpha_d < \alpha < \alpha_c$ 为动力学 1RSB，$\alpha_c < \alpha < \alpha_s$ 为静态 1RSB，以上为 UNSAT。随机 4-SAT 在 $\alpha \ge \alpha_d \simeq 9.38$ 出现点到集合长程关联，见图 22.2；其平台宽度随 α 增长，并在 α_d 发散，是动力学 1RSB 转变的典型特征。

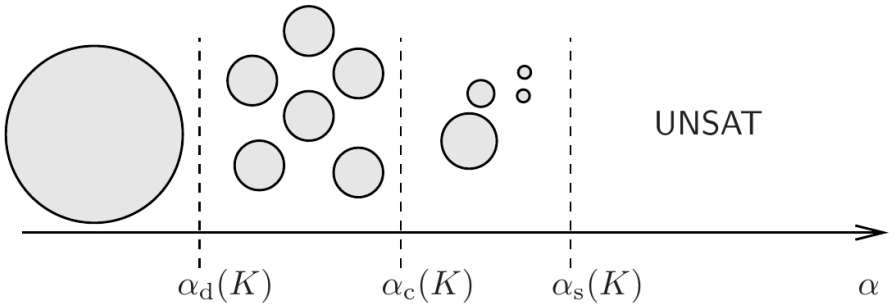


图 22.1: $K \ge 4$ 时随机 K-SAT 随单位变量子句数 α 的相示意。从左到右为 RS、动力学 1RSB、静态 1RSB 和 UNSAT。

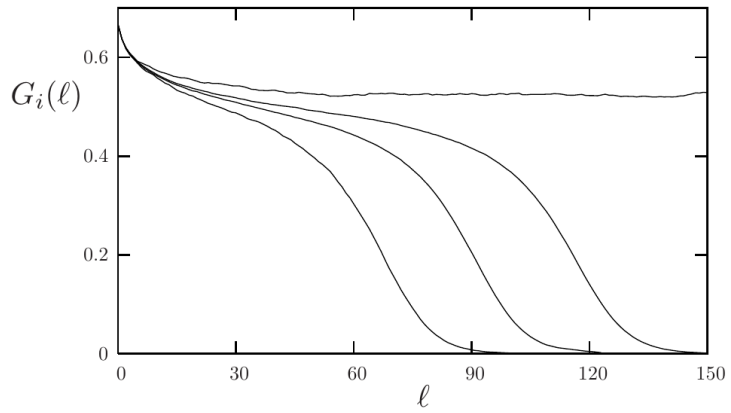


图 22.2: 随机 4-SAT 的点到集合关联 (22.14) 随距离变化，子句密度自下至上为 9.30、9.33、9.35、9.40。

22.2 更高阶的复本对称性破缺

本书某些模型被认为可由 RS 或 1RSB 渐近精确求解，但一般需要更高阶 RSB。下面概述局部树状图模型中逐层构造高阶解的方法。特别是理解 2RSB 结构后可导出 1RSB 稳定性判据；第 20 章 SAT–UNSAT 阈值的精确性猜想就是以它为部分依据。

22.2.1 总体图景

先回顾 RS 与 1RSB。对式 (22.1) 的局部树状因子图，RS 腔方法用消息集 $\{\nu_{i\to a}\},\{\widehat{\nu}_{a\to i}\}$ 准确描述局部边缘。给定节点集 U 诱导的小树状子图，图的其余部分对 U 的影响由边界上的因子化测度描述。

1RSB 允许一种特定结构的长程关联，将 μ 假定为 Bethe 测度 μ^r 的凸组合。每个态内部的局部边缘由一套消息 $\{\nu^r_{i\to a}\}$ 在大 N 时渐近精确描述。随机抽态就得到消息上的分布 $\mathcal{P}(\{\nu\},\{\widehat{\nu}\})$；它由原模型自然导出的辅助图模型描述。辅助因子图继承原图结构，仍局部树状。1RSB 就是以 RS 方法研究该辅助消息模型。

然而，辅助分布本身也可能分解为多个纯态，导致 1RSB 失效。高阶 RSB 便重复这一步：2RSB 用 1RSB 研究辅助分布，也就是再引入一层辅助模型并用 RS 求解。其直观解释是原构型空间中的纯态团块具有层级组织，被分成云团；每个团块有云团指标 r_1 和云内指标 r_2：

$$\mu(x)=\sum_{r_1\in S_1,\,r_2\in S_2(r_1)} w_{r_1,r_2}\mu^{r_1,r_2}(x). \tag{22.16}$$

$S_2(r_1)$ 是云团内各团块的指标集，见图 22.3。

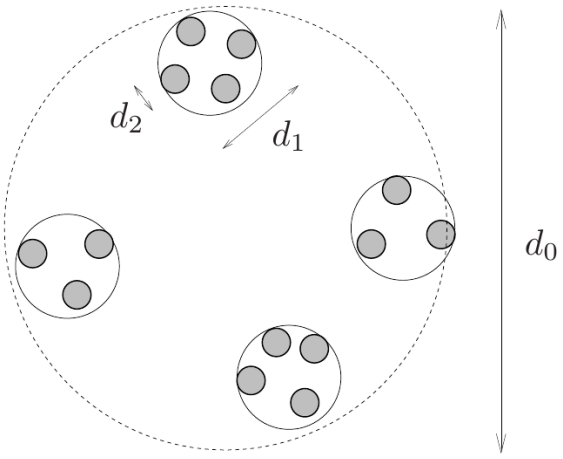


图 22.3: 2RSB 模型的分布示意。质量集中在半径 d_2 的灰色团块中，团块组成半径 $d_1 > d_2$ 的云团；虚线圆表示云团间典型距离 d_0。

即使最宽容的读者也应问：N_1 个云团、每云 N_2 个团块，与直接有 N_1N_2 个团块有何不同？原句第一处将每云团块数也印为 N_1。区别可通过从 μ 独立抽取的两个复本间适当距离，如除以 N 的 Hamming 距离看出。分别以同一团块、同云不同团块、不同云为条件，归一化距离集中在 $d_2 < d_1 < d_0$ 三值附近。类似 1RSB，可依相关云团和团块的数目区分动力学与静态 2RSB。最常研究的静态 2RSB 中这些数目为次指数，故渐近距离分布在三值均有非零质量，或说 $P(q)$ 是三个 Dirac 峰的组合。

可继续把云团组成更大结构。k-RSB 下，μ 是纯态 μ^r 的凸组合，$r = (r_1, \dots, r_k)$ 编号一棵 k 代树的叶子，指标依次是根到叶路径的节点。由此得到辅助图模型层级。允许任意大 k，预期能确定广泛模型的渐近性质，如单位变量自由熵 $\phi = \lim_{N\to\infty} N^{-1} \log Z_N$。这给出第 8 章的自然超度量结构，图 22.4 再次展示。广义随机能量模型 GREM 捕捉这种结构，是第 5 章 REM 的推广；完整求解超出范围，但其定义很有启发性。

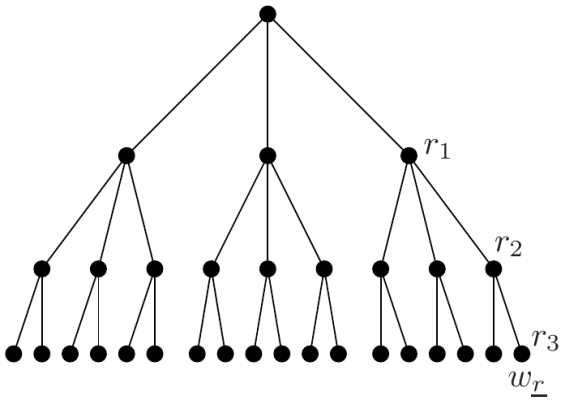


图 22.4: k 步复本对称性破缺中分布的层级结构，此处 $k = 3$。

例 22.4 (GREM)**.** 这是 k 步 *RSB* 分布的简单模型，系统尺度 $N \in \mathbb{N}$，另有在 $N \to \infty$ 时固定的参数 $\{a_0, a_1, \dots, a_{k-1}\}$、$\{d_0, d_2, \dots, d_{k-1}\}$ 和 $\{\Sigma_0, \dots, \Sigma_{k-1}\}$。态对应 k 代树的叶子，由路径 $r = (r_0, \dots, r_{k-1})$ 编号。模型不描述单态内部结构（可把单态支撑看成一个构型），只描

述态间距离与分解权重。

第 i 层节点有 $\exp\{N\Sigma_i\}$ 个子节点，态数为 $\exp\{N\sum_i \Sigma_i\}$。从态 r,s 抽出的构型距离为 $d_{i(r,s)}$，原文将 $i(r,s)$ 定义为使 $r_i = s_i$ 的最大整数。态权重为

$$w_r = \frac{1}{Z}\exp\{-\beta(E_{r_0}^{(0)} + \cdots + E_{r_{k-1}}^{(k-1)})\}, \tag{22.17}$$

其中 $E_r^{(i)}$ 是均值 0、方差 Na_i 的独立正态变量。读者可推导热力学性质，如随温度变化的自由能。

译注： 参数列表漏了 d_1；层级距离应依据共同祖先或共同路径前缀。若 r_i 仅是各父节点内的局部子节点编号，后来偶然相等并不表示共同祖先，能量也须按真实路径节点编号。源简写照录，不据此替换模型。

22.2.2 2RSB 的形式

高阶 RSB 在第 8 章的全连接 p 自旋 Ising 等模型中已有详细研究；稀疏图上的任何超出 1RSB 的计算却都很困难。下面只形式地建立 2RSB 腔计算，不试图证明。

为简化，设式 (22.1) 只有两体相互作用，因子度均为 2，故可像第 14.2.5 节一样沿普通图边只传一类消息。取度 $l+1$ 的变量节点 0，邻居中的 l 个为 $1,\dots,l$，其输入消息为 $\nu_1,\dots,\nu_l$，ν_0 为向最后一个邻居的输出。RS 腔方程为

$$\nu_0(x_0) = \frac{1}{z\{\nu_i\}}\prod_{i=1}^{k}\sum_{x_i}\psi_{0i}(x_0,x_i)\nu_i(x_i), \tag{22.18}$$

其中 z 由归一化确定，简写 $\nu_0 = f_0\{\nu_i\}$。每个消息是 $(|\mathcal{X}|-1)$ 维单纯形中的点。**译注：** 这里输入数为 l，原乘积上限却印为 k；保留。

1RSB 将消息提升为分布 Q_i 下的随机变量，见第 19 章。将实参数记为 x_1，连续记法给出

$$Q_0(\nu_0) = \frac{1}{\mathcal{Z}\{Q_i\}}\int z\{\nu_i\}^{x_1}\delta(\nu_0 - f_0\{\nu_i\})\prod_{i=1}^{l} dQ_i(\nu_i). \tag{22.19}$$

简写 $Q_0 = F_0\{Q_i\}$；F_0 将 l 个单纯形上的分布映射到一个新分布。

2RSB 再次将 Q_i 提升为随机变量，其取值为单纯形上的概率分布；它们的分布记为 $\mathcal{Q}_i$，并引入另一个实参数 x_2：

$$\mathcal{Q}_0(Q_0) = \frac{1}{\mathfrak{Z}\{\mathcal{Q}_i\}}\int \mathcal{Z}\{Q_i\}^{x_2/x_1}\delta(Q_0 - F_0\{Q_i\})\prod_{i=1}^{l} d\mathcal{Q}_i(Q_i). \tag{22.20}$$

这里是实数紧子集上的分布的分布，可能看起来吓人。更合乎数学的表述是，对任意分布的可测集合 A 要求

$$\mathcal{Q}_0(A) = \frac{1}{\mathfrak{Z}\{\mathcal{Q}_i\}}\int \mathcal{Z}\{Q_i\}^{x_2/x_1}\mathbb{I}(F_0\{Q_i\}\in A)\prod_{i=1}^{l} d\mathcal{Q}_i(Q_i). \tag{22.21}$$

[1] **译注：** 原正文在此将单纯形维数写为 $|\mathcal{X}|$，脚注及前文为 $|\mathcal{X}|-1$；此处沿用后者。比值 x_2/x_1 需要 $x_1\neq 0$，零值情形须另取适当极限。为区别两层归一化，这里用 $\mathcal{Z}$ 与 $\mathfrak{Z}$ 表示源稿的两种 Z 字形。

其解释与 1RSB 类似。设 α_1 编号某一云团，$Q_i^{\alpha_1}$ 是云内团块间消息 ν_i 的分布；按依赖 x_1 的权重抽取云团时，$Q_i^{\alpha_1}$ 的分布就是 $\mathcal{Q}_i$。

原则上可推广第 19 章种群动力学数值研究它。对一个给定实例推广 SP，每条有向边要存一个种群的种群；若再统计研究消息、寻找密度演化不动点，就需要种群的种群的种群！内存与时间均很昂贵。就作者所知，当时仅有一次尝试：计算随机 5-正则图自旋玻璃基态能量。因正则图从任意点看有限距离内相同，可令所有边 $\mathcal{Q}_i$ 相同，从而降回两层种群。源书表 17.4.5 汇总结果：相对 1RSB，2RSB 基态能修正约 10^{-4}，似乎与数值估计一致。**译注：** 本冻结材料缺正式第 17 章，所指表无法在本译本内核对，不补造表项。

22.2.3 1RSB 相的局部稳定性

先理解 2RSB 退化到 1RSB 的两种方式。第一种显然方式是让 $\mathcal{Q}_i$ 为 Q_i^* 处的 Dirac 质量；对分布空间上任意连续泛函 $\mathcal{F}$，

$$\int \mathcal{F}(Q_i)\,d\mathcal{Q}_i(Q_i)=\mathcal{F}(Q_i^*). \tag{22.22}$$

若 $\{Q_i^*\}$ 解 1RSB 方程，则它对任意 x_2 都解 2RSB 方程。

第二种让 $\mathcal{Q}_i$ 非平凡，却仅支撑在 Dirac 分布上。记 δ_{ν^*} 为消息 ν^* 处的 1RSB Dirac 分布。给定 1RSB 解 Q_i^*，将各 δ_{ν^*} 按 $Q_i^*(\nu^*)$ 权重混合：

$$\int \mathcal{F}(Q_i)\,d\mathcal{Q}_i(Q_i)=\int \mathcal{F}(\delta_{\nu^*})\,dQ_i^*(\nu^*). \tag{22.23}$$

习题 22.2. 设 $\{Q_i^*\}$ 解把 *1RSB* 参数由 x_1 换成 x_2 的式 (22.19)。证明式 (22.23) 的 $\mathcal{Q}_i$ 对任意 x_1 解 *2RSB* 方程。提示：在 *Dirac* 分布上，两层归一化满足 $\mathcal{Z}\{\delta_{\nu_i}\}=z\{\nu_i\}^{x_1}$。

这对应两种不同极限。第一种云团分布退化，实质上只有一个云团；这里指云团数不随 N 指数增长，复杂度为 0。第二种则是云内分布平凡，每云只有一个簇，“只有一个” 也取同样意义。

1RSB 在 BP 消息分布空间求解，称为 1RSB 空间。2RSB 在更大的消息分布的分布空间求解；两式给出前者嵌入后者的两种方式。找到 1RSB 解，自然要问是否还有落在子空间之外的真正 2RSB 解。若没有，物理学家通常猜想 1RSB 渐近正确，例如给出正确自由能密度。全连接 p 自旋模型已有这种检查；稀疏因子图则因 2RSB 方程太难而尚不能实施。

较方便但较弱的替代是检查对高阶 RSB 的局部稳定性。用两种嵌入把 1RSB 解视作 2RSB 中的点，对其施加小扰动，迭代

$$\mathcal{Q}_{i\to j}^{(t+1)}(Q_0)=\frac{1}{\mathfrak{Z}\{\mathcal{Q}_{l\to i}\}}\int \mathcal{Z}\{Q_{l\to i}\}^r\delta(Q_{i\to j}-F_i\{Q_{l\to i}\})\prod_{l\in\partial i\setminus j}d\mathcal{Q}_{l\to i}^{(t)}(Q_{l\to i}).$$

[1] 给定可测空间 Ω，此处为 $(|\mathcal{X}|-1)$ 维单纯形，其上概率分布的集合可赋予使 2RSB 方程有意义的可测结构：取让每个可测 $A\subseteq\Omega$ 的映射 $Q\mapsto Q(A)$ 都可测的最小 σ 域。

在适当扰动参数上线性化，看是否回到 1RSB 不动点；不回去则称不稳定。相对第一种嵌入的不稳定称 I 型，第二种称 II 型。**译注：**此未编号原式左侧用 Q_0，Dirac 约束却用 $Q_{i\to j}$；重权指数简写为 r，须与前式的 x_2/x_1 对应。保留源形式。

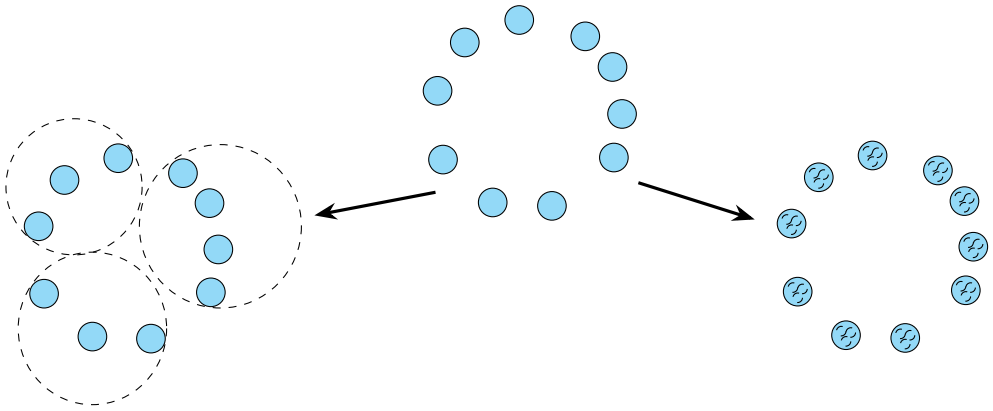


图 22.5: 1RSB 解向 2RSB 发生的两类局部不稳定性示意。

另一方法是计算描述单点扰动响应的磁化率。前述线性响应在 $\chi^{(2)}$ 有限时保持有限，故可假定 1RSB 正确，算它并检查有限性。但 1RSB 还要求每个团块本身稳定。定义对态内测度 μ^r 的磁化率 $\chi_{\mathrm{SG},r}$，再按态权重平均：

$$\chi_{\mathrm{SG,intra}} = \sum_r w_r \chi_{\mathrm{SG},r}, \tag{22.24}$$

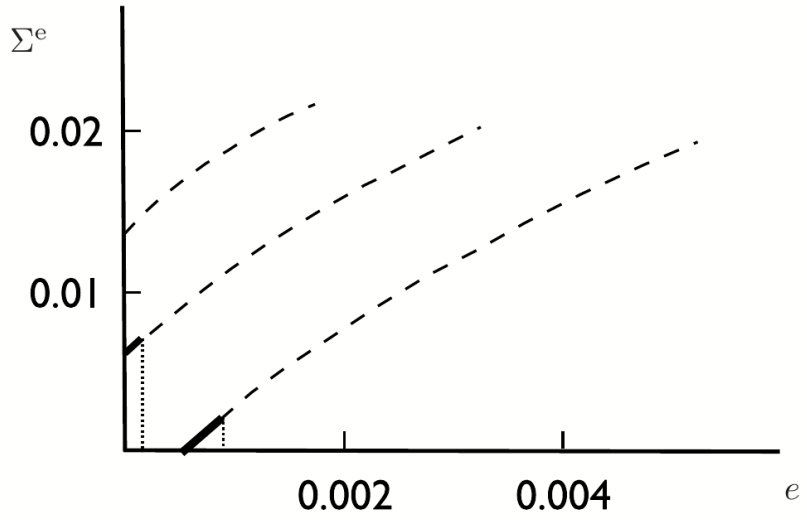
$$\chi_{\mathrm{SG},r} = \frac{1}{N}\sum_{i,j} (\langle x_i x_j\rangle_r - \langle x_i\rangle_r\langle x_j\rangle_r)^2. \tag{22.25}$$

第二个条件便是用 1RSB 计算 $\chi_{\mathrm{SG,intra}}$，要求 $N\to\infty$ 时仍有限。一般相信两种局部稳定性检查等价：I 型对应 $\chi^{(2)}$ 有限，表示态不再成簇聚合；II 型对应态内磁化率有限，表示态不再裂成子态，见图 22.5。这一等价性已在若干特例研究，一般情形仍是猜想。值得注意的是，若干有趣模型中 1RSB 确实不稳定，需要更高阶 RSB 才能得到精确预测。

稳定性计算较复杂，超出本书范围，但可举随机 K-SAT 为例。设 $M = N\alpha$，大系统极限每变量最低违反子句数为 $e_s(\alpha)$。第 20 章 1RSB 方法先计算随违反密度 e 变化的能量复杂度 $\Sigma_e(e)$，再找使其为正的最小能量。$\alpha < \alpha_s(K)$ 时 $e_s = 0$，以上连续离开 0 并单调增长。原文这里将最小值的自变量写为 u，与 e 混用。

对给定 α，一般在 $e > e_G(\alpha)$ 出现 II 型不稳定，只有 $e \le e_G$ 的复杂度曲线局部稳定。若 $\alpha < \alpha_m(K)$，$e_G = 0$、整条 1RSB 计算不稳定；若 $\alpha > \alpha_G(K)$，$e_G < e_s$，基态预测也不稳定，原文据此判断不正确。因此稳定区间为 $]\alpha_m, \alpha_G[$，对所有 K 都含 SAT–UNSAT 阈值 α_s。图 22.6 汇总 3-SAT 结果。

稳定性检查支持阈值预测精确的猜想，但必须强调：只检查了小扰动。若能直接进行 2RSB 计算，证明除了上述两种嵌入解外没有其他解，才是更强的论据。



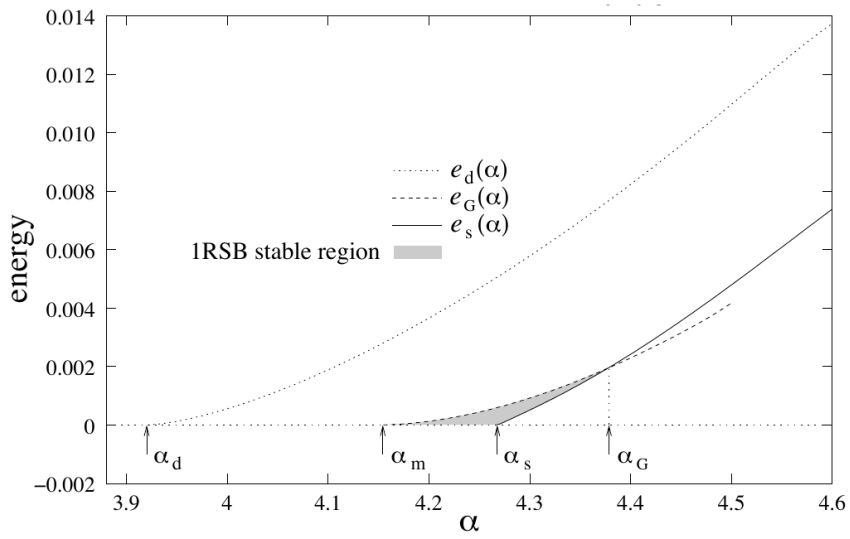


图 22.6: 上：随机 3-SAT 的 1RSB 能量复杂度对违反子句密度，$\alpha = 4.1, 4.2, 4.3$（自上至下），重现图 20.5 并标稳定性。e_G 以下粗实线是局部稳定部分；$4.1 < \alpha_m(3)$ 时整条曲线均不稳定。原文只将稳定部分称为 1RSB 可靠计算部分，虚线不稳定。下：实线为 1RSB 预测的最低违反密度（复杂度开始为正的能量），点线为阈值能量（复杂度存在的最大能量），灰区为局部稳定区域。$\alpha > \alpha_G$ 的基态预测因高阶 RSB 不稳定而错误，虽可能很接近真值。猜想 $\alpha_m < \alpha < \alpha_s$ 为 1RSB 相；若成立，则 SAT 阈值预测正确。$K = 3$ 时 $\alpha_m = 4.153(1)$、$\alpha_s = 4.2667(1)$、$\alpha_G = 4.390(5)$。

22.2.4 腔方法内部的开放问题

主要问题当然是证明某些模型的 1RSB 预测正确；截至源稿写作时，仅对一类全连接模型实现。这里列出即使在启发式层面也未解决的问题。

分布方程。 预测由式 (22.19) 一类方程的不动点表达。在随机图系综中，可将其视为 Q_0 分布的方程，并要求它与 $Q_1, \dots, Q_k$ 同分布。当时主要工具是第 14.6.4 节种群动力学，另一条已探索路线是大度数形式展开。种群方法强大而通用，但常太粗，特别是 $k \geq 2$ 时；统计误差按种群大小的平方根倒数衰减。在大而有界平均度的图系综等模型中，当时普通 PC 能实现的 10^7–10^8 元素种群仍有太大波动，难以分辨需要高精度的 2RSB 和 1RSB 差异。亚稳性本身也是种群动力学的核心困难与限制。因此希望：

- 发展腔方程的解析工具与一般结果，为数值研究提供指导。
- 发展高效、稳定的新数值方法。

第 19.5 定理中的重构算法是一项进展，但仅适用于 $x = 1$。

局部稳定性。 它是启发式研究的重要指引，但需更坚实基础，例如：

- 证明若所有 1RSB 解都局部不稳定，则 1RSB 子空间外必有 2RSB 解。
- 证明局部不稳定的腔方程解不能正确描述模型。

k-RSB 的出现。 已研究的随机模型大多是 RS、1RSB 或 FRSB。2RSB 少见，且总涉及特别构造的相容函数，例如叠加 $p_1 = 3$、$p_2 = 16$ 两种相互作用的全连接自旋玻璃。希望找到渐近精确的自然 2RSB 模型，或理解为何不可能。

完全复本对称性破缺。 k 增长给出嵌套的局部边缘、自由熵等渐近计算方案；高阶可行解空间中嵌入所有低阶方案，但分布的分布层层增加，空间愈加复杂。全连接模型在 $k \to \infty$ 的 FRSB 极限竟有紧凑描述；稀疏图能否找到类似描述，是重要开放问题。这将允许同时在全部 k 的空间中寻找最佳解。

- 描述稀疏图模型的完全复本对称性破缺消息空间。

变分性质。 广泛相信，腔 k-RSB 方程的一致解所算自由能密度，始终是真实自由能密度的下界，特别地其基态能密度也是真实值的下界。对广泛具有统计 $+1/-1$ 对称性的模型应当如此；虽已在某些特例证明，仍希望：

- 一般证明腔方法给出的自由能是真实自由能的下界。

22.3 相结构与算法行为

本书相当篇幅讨论随机图模型的相与算法行为的联系。经验、启发式乃至某些严格结果已提供大量证据。例如第 21 章编码中，1RSB 相及大量亚稳态的出现决定 BP 失败的噪声阈值。更广泛理解这种联系，并确定适用的算法类别，是重要问题。以下提出一些研究方向，始终考虑式 (22.1) 且因子图局部树状。

动力学转变对 Monte Carlo 动力学的影响。 考虑从该分布采样的 MCMC，每步翻转次线性 $o(N)$ 个变量，并相对 μ 满足细致平衡。预期 1RSB 相内弛豫时间随尺度迅速、可能指数增长。第 22.1 节两种刻画均支持此观点：纯态分解给出穿越瓶颈的时间，另见第 13 章；关联刻画则通过 $G_i(\ell)$ 定义长度 ℓ_i^*，弛豫需信息传播该距离，若它随系统发散，弛豫时间也应发散。

这一图景直观却远未证明，还需更精确表述。例如 RS 相中也可能有小而孤立的亚稳态，使 MCMC 的逆谱隙形式上很大；数值 Glauber 动力学却仍迅速平衡。这可能因为初态均匀随机，且仅用局部可观测量检查平衡。于是问：

- RS 相中亚稳性为何在实践中不重要？是因为只测局部量，还是因为均匀初态？若是后者，均匀初态有何特别？
- RS 相中能否高效近似配分函数？

消息传递与边缘估计。 稀疏随机图上一些模型处于 RS、有时动力学 1RSB 相时，BP 或 SP 经验上表现良好：从均匀消息开始，能良好近似局域期望。现有严格分析常试图证明与初始化无关的准确性，因而被实践中不用的最坏初值主导。例如随机 K-SAT 解均匀测度的 BP，最坏初始化分析仅证明 $\alpha \le (2\log K)/K[1+o(1)]$ 时准确，远小于终止 RS 相的 $\alpha_d(K) = 2^K \log K/K[1+o(1)]$。

一般并不能在数学上充分控制 BP 或 SP 何时收敛、何时准确。经验上，SP 能在某些 BP 不收敛的 1RSB 区域收敛；除 1RSB 正确描述关联这一粗略论据外，我们仍不真正理解。开放问题包括：

- 对随机实例和均匀随机初始化，BP/SP 为何远胜最坏情形？均匀初始化有什么特别？随机实例哪些特征使其更易求解，能否高效刻画和检查？
- BP/SP 何时收敛并近似局部边缘？朴素迭代不收敛时，能否系统强制收敛，或改用消息时间平均？
- 稀疏随机图上，BP/SP 似乎优于局域 MCMC，原则上能在动力学 1RSB 相表现良好；能否在某模型中令人信服地证明这种可能性？

消息传递与优化。 目前用消息传递寻找随机约束满足解的主要方法是抽取固定：先算局部边缘，据此固定一个变量，再迭代。约束密度不大时通常成功，高于某个严格小于 SAT 阈值的临界密度则失败；尚无人能解析确定此阈值。另一条路线是强化：根据同样的边缘信息修改每个变量上的局域因子，而非直接固定变量；优化这种修改仍靠经验，临界阈值也无法估计。

- 如何预测 BP 或 SP 加抽取固定的性能？经验上它们在 $\alpha < \alpha_{\mathrm{BP}}(K)$ 或 $\alpha < \alpha_{\mathrm{SP}}(K)$ 时以高概率找到解，但这些算法阈值无预测。哪些问题中 SP 优于 BP？
- 对 BP 或 SP 加强化提出同样问题。
- 如何新利用消息传递给出的局部边缘信息构造解？
- UNSAT 相中消息传递能估计最低违反约束数；能否用这个估计及消息内的信息，证明某个给定实例不可满足？

以上聚焦稀疏随机实例。针对它们，消息方法已得到部分理解与改进；许多应用本就通过设计得到随机或伪随机图。稀疏图码是明显例子，大码长下随机构造通常优于确定构造。更近来，稀疏图还用于无损及有损压缩、在线网络测量、多端通信、分布式存储、群体测试等。

若能处理结构化图，应用将更广。但这类问题常使消息不收敛；即使原问题边缘估计准确，固定很多变量后的剩余实例不再随机，也常导致抽取法失败。因此，寻找适合结构化图的消息传递改进非常有意义。

- 如何用消息传递改进一般非随机约束满足问题的求解？能否与 MCMC 等通用方法有效结合？

注释

本章不可避免地简略；以下仅给一些近期研究入口，不求全面。**译注：**以下“近期”、未解及计算机资源等判断均属于冻结作者草稿的写作时期。

关联长度与相变的联系是经典统计力学主题，玻璃转变研究使其再受关注。玻璃语境的入门可看 Bouchaud and Biroli (2004)，其中描述了第 22.1.2 节的冻结思想实验。

点到集合关联的重构解释来自 Evans, Kenyon, Peres and Schulman (2000)，研究树上 Ising 模型的重构相变。树上广泛模型的综述见 Mossel and Peres (2003)、Mossel (2004)；非树图推广见 Gerschenfeld and Montanari (2007)。重构与动力学 1RSB 转变的联系由 Mézard and Montanari (2006) 首先指出；动力学影响见 Berger, Kenyon, Mossel and Peres (2005)、Martinelli, Sinclair and Weitz (2004)、Montanari and Semerjian (2006b)。本章纯态定义以及随机 SAT 和随机图着色的动力学、凝聚转变位置来自 Krzakala, Montanari, Ricci-Tersenghi, Semerjian and Zdeborova (2007)。

GREM 由 Derrida (1985) 提出，Derrida and Gardner (1986) 详细研究。全连接模型的 2RSB 相见 Crisanti and Leuzzi (2007)。稀疏随机图的高阶 RSB 结果很少；自旋玻璃可在临界点附近作微扰展开（Viana and Bray, 1985），或作大度数展开（Goldschmidt and Dominicis, 1990）。第 22.2 节提及的 2RSB 基态能计算来自 Montanari (2003)。稀疏系统 1RSB 局部稳定性检查由 Montanari and Ricci-Tersenghi (2003) 首先建立，Montanari, Parisi and Ricci-Tersenghi (2004) 将其用于随机可满足性。随机 K-SAT 稳定性阈值及渐近行为的完整列表见 Mertens, Mézard and Zecchina (2006)。磁化率解释见 Rivoire, Biroli, Martin and Mézard (2003)。

在某些全连接模型中，Guerra (2003) 的不等式能证明腔或复本方法自由能是真值的下界。同一策略在部分稀释系统也给出严格界（Franz and Leone, 2003; Franz, Leone and Toninelli, 2003; Panchenko and Talagrand, 2004），但仍依赖具体模型结构，缺乏适用于全部情形的一般证明。SAT 强化算法由 Chavas, Furtlehner, Mézard and Zecchina (2005) 提出并讨论。解空间结构的算法后果仅有少量结果，近期分析见 Altarelli, Monasson and Zamponi (2007)、Montanari, Ricci-Tersenghi and Semerjian (2007)、Ardelius and Aurell (2006)、Alava, Ardelius, Aurell, Kaski, Krishnamurthy, Orponen and Seitz (2007)。足够小密度随机 K-SAT 的 BP 收敛与准确性由 Montanari and Shah (2007) 证明。

本书只涵盖信息论、计算机科学和统计物理交叉处一小部分问题，未谈主题难以穷举，只给一些入口。信道编码只是信息论基本问题之一；数据压缩，尤其有损压缩，是许多现代技术

的关键且仍有开放问题（Ciliberti, Mézard and Zecchina, 2005; Wainwright and Maneva, 2005）。群体测试等统计问题与压缩精神类似（Mézard, Tarzia and Toninelli, 2007）。

现代无线和有线通信本质上是多用户系统，寻找最优多用户编码有巨大实际意义却远未解决，甚至信息论容量也未知。统计力学工具或类比有益于多用户检测（Tanaka, 2002; Guo and Verdú, 2002）和网络研究（Kelly, 1991）。在通信背景下，人们也大量研究互联网等大型通信网络；有用综述见 Kleinberg, Kumar, Raghavan, Rajagopalan and Tomkins (1999)。

统计力学概念还用于金融市场涨落（Bouchaud and Potters, 2003）、经济主体相互作用（Challet, Marsili and Zhang, 2005）。生物学中，随机性、组分相互作用与稳健性同样重要；网络随机模型和推断算法已用于神经网络（Baldassi, Braunstein, Brunel and Zecchina, 2007; Coolen, Kuehn and Sollich, 2005）、系统发育（Mossel, 2003）和基因表达（Friedman, Linial, Nachman and Peér, 2000）。其中一些及其他主题见近期暑期学校文集 Bouchaud, Mézard and Dalibard (2007)。

附录 A　符号与记号

本附录汇总全书符号约定。第 A.1、A.2 节讨论等价关系与增长阶，第 A.3 节介绍组合与概率记法；后四节分别汇总数学、信息论、因子图、消息传递与腔方法的记号。

A.1　等价关系

通常 $=$ 表示相等，$\equiv$ 表示定义，$\approx$ 表示数值接近。例如 Euler–Mascheroni 常数为

$$\gamma_E \equiv \lim_{n\to\infty}\left\{\sum_{k=1}^{n}\frac{1}{k}-\log n\right\}\approx 0.5772156649. \tag{A.1}$$

随机变量 X, Y 同分布记为 $X \overset{d}{=} Y$。例如 $X_0,\dots,X_n$ 为独立同分布的零均值、单位方差 Gaussian 变量，则

$$X_0 \overset{d}{=} \frac{1}{\sqrt{n}}(X_1+\cdots+X_n). \tag{A.2}$$

本书用若干等价符号描述函数在某极限下的行为。为简单起见设整数 $n\to\infty$；具体问题的极限应由上下文明确。若 f, g 在主导指数阶相等，记为 $f(n)\doteq g(n)$，即

$$\lim_{n\to\infty}\frac{1}{n}\log\frac{f(n)}{g(n)}=0. \tag{A.3}$$

例如

$$\binom{n}{\lfloor n/2\rfloor}\doteq 2^n. \tag{A.4}$$

若渐近相等至一个常数因子，写 $f(n)\sim g(n)$，即某个常数 $C\neq 0$ 满足

$$\lim_{n\to\infty}\frac{f(n)}{g(n)}=C. \tag{A.5}$$

例如

$$2^{-n}\binom{n}{\lfloor n/2\rfloor}\sim n^{-1/2}. \tag{A.6}$$

符号 $\simeq$ 专用于比值趋于 1 的渐近相等：

$$\lim_{n\to\infty}\frac{f(n)}{g(n)}=1, \tag{A.7}$$

$$2^{-n}\binom{n}{\lfloor n/2\rfloor}\simeq\sqrt{\frac{2}{\pi n}}. \tag{A.8}$$

译注： 这里 $\sim$ 与 $\simeq$ 是作者的特定约定，可能不同于其他文献；对数和比值公式还需满足相应正性及非零分母条件。

$\cong$ 则表示相差一个常数。若 p, q 是同一有限空间上的测度，不必归一化，$p(x) \cong q(x)$ 表示存在 $C > 0$，使任意 x 有

$$p(x) = Cq(x). \tag{A.9}$$

无限空间上相应要求两测度的 Radon–Nikodym 导数为正常数。

A.2 增长阶

这里仍取整数 $n \to \infty$，其他极限可类推。若存在正常数 C_1, C_2，使充分大 n 时

$$C_1 g(n) \le |f(n)| \le C_2 g(n), \tag{A.10}$$

则写 $f(n) = \Theta(g(n))$，称 f 与 g 同阶。例如

$$\sum_{k=1}^{n} k = \Theta(n^2). \tag{A.11}$$

若

$$\lim_{n\to\infty} \frac{f(n)}{g(n)} = 0, \tag{A.12}$$

则写 $f(n) = o(g(n))$。例如

$$\sum_{k=1}^{n} k - \frac{1}{2}n^2 = o(n^2). \tag{A.13}$$

最后，若存在常数 C 使充分大 n 时

$$|f(n)| \le Cg(n), \tag{A.14}$$

则写 $f(n) = O(g(n))$。例如

$$n^3 \sin(n/10) = O(n^3). \tag{A.15}$$

$\Theta(g)$ 和 $o(g)$ 都蕴含 $O(g)$，反之未必，如最后一例所示。**译注：** 这些增长阶不等式通常取最终非负、比值处非零的比较函数 g，且上界常数为正；源文未逐次重述。

A.3 组合与概率

多项式系数用标准记法：$n \ge 0, l \ge 2$、$n_1, \ldots, n_l \ge 0$ 且总和为 n 时，

$$\binom{n}{n_1, n_2, \ldots, n_l} \equiv \frac{n!}{n_1! n_2! \cdots n_l!}. \tag{A.16}$$

二项式系数是 $l=2$ 的通常简写：

$$\binom{n}{k} \equiv \binom{n}{k, l-k} = \frac{n!}{k!(n-k)!}. \tag{A.17}$$

译注： 中间下标源印为 $k, l-k$，应与总和 n 的条件核对，通常应为 $k, n-k$；照录源式。

组合量常用生成函数描述。对形式幂级数，$\operatorname{coeff}\{f(x), x^n\}$ 表示单项式 x^n 的系数：

$$f(x) = \sum_n f_n x^n \quad \Longrightarrow \quad f_n = \operatorname{coeff}\{f(x), x^n\}. \tag{A.18}$$

例如

$$\operatorname{coeff}\{(1+x)^m, x^n\} = \binom{m}{n}. \tag{A.19}$$

常用随机变量如下：

- Bernoulli 参数 p 变量取值 0、1，且 $\mathbb{P}(X=1)=p$。
- $B(n,p)$ 为参数 n, p 的二项变量，取值 $0, \ldots, n$，

$$\mathbb{P}\{B(n,p)=k\} = \binom{n}{k} p^k (1-p)^{n-k}. \tag{A.20}$$

- 参数 λ 的 Poisson 变量取整数值，分布为

$$\mathbb{P}\{X=k\} = \frac{\lambda^k}{k!} e^{-\lambda}. \tag{A.21}$$

参数也是均值；此处的整数指非负整数。

最后，δ_a 是 Dirac 质量，实际上是向单点 a 赋予单位质量的测度；任意集合 A 有

$$\delta_a(A) = \mathbb{I}(a \in A). \tag{A.22}$$

A.4 数学记号汇总

$=$	相等。
$\equiv$	定义为。
$\approx$	数值接近。
$\overset{d}{=}$	同分布。
$\doteq$	主导指数阶相等。
$\sim$	渐近相等至常数因子。
$\cong$	相差归一化常数，概率情形见式 (14.3)。
$\Theta(f)$	与 f 同阶，见第 A.2 节。
$o(f)$	比 f 增长慢，见第 A.2 节。
$\arg\max f(x)$	实函数达到最大值的 x 的集合。

$\lfloor\cdot\rfloor$	向下取整：$\lfloor x\rfloor$ 是不大于 x 的最大整数。
$\lceil\cdot\rceil$	向上取整：$\lceil x\rceil$ 是不小于 x 的最小整数。
$\mathbb{N},\mathbb{R}$	整数集合、实数集合。
$\beta\downarrow\beta_c$	从大于 β_c 的值趋近。
$\beta\uparrow\beta_c$	从小于 β_c 的值趋近。
$]a,b[$	$a<x<b$ 的实数开区间。
$]a,b]$	$a<x\le b$ 的实数区间。
$\mathbb{Z}_2$	模 2 整数域。
$a\oplus b$	两整数之和模 2。
$\mathbb{I}(\cdot)$	示性函数：命题真时为 1，假时为 0。
$A\succeq 0$	矩阵 A 半正定。

译注：原表称 $\mathbb{N}$ 为整数集合，未明确是否包含 0；通常以它表示自然数，而全体整数用 $\mathbb{Z}$，使用时需依上下文核对。

A.5 信息论

H_X	随机变量 X 的熵，式 (1.7)。
I_{XY}	随机变量 X,Y 的互信息，式 (1.25)。
$\mathcal{H}(p)$	参数 p 的 Bernoulli 变量的熵。
$\mathfrak{M}(\mathcal{X})$	有限集 $\mathcal{X}$ 上的概率分布空间。
$\mathfrak{C}$	码本。
$\preceq$	BMS(1) $\preceq$ BMS(2) 表示信道 2 相对信道 1 物理退化。
$\mathfrak{B}$	信道的 Bhattacharyya 参数。

A.6 因子图

$\mathbb{G}_N(k,M)$	有 N 个变量、M 个函数节点的随机 k 因子图。
$\mathbb{G}_N(k,\alpha)$	N 个变量节点的随机 k 因子图，每个可能函数节点以概率 $N\alpha/\binom{N}{k}$ 独立存在。
$\mathbb{D}_N(\Lambda,P)$	度约束随机因子图系综。
$\mathbb{T}_r(\Lambda,P)$	度约束随机树因子图系综。
$\mathbb{T}_r(k,\alpha)$	$\mathbb{T}_r(\Lambda(x)=e^{k\alpha(x-1)},P(x)=x^k)$ 的简写。
$\Lambda(x),P(x)$	分别为变量、函数节点的度分布多项式。
$\lambda(x),\rho(x)$	分别为边视角的变量、函数节点度分布多项式。
$B_{i,r}(F)$	变量节点 i 的半径 r 邻域。
$B_{i\to a,t}(F)$	一条边的有向邻域。

A.7 腔方法与消息传递

$\nu_{i\to a}(x_i)$	BP 消息，变量到函数节点。
$\widehat{\nu}_{a\to i}(x_i)$	BP 消息，函数到变量节点。
Φ	自由熵。
$\mathbb{F}(\nu)$	Bethe 自由熵，作为消息的函数。
$\mathbb{F}^e(\nu)$	Bethe 能量，作为最小和消息的函数。
f^{RS}	Bethe 或 RS 自由熵密度。
$Q_{i\to a}(\nu)$	1RSB 腔消息或 SP 消息，变量到函数。
$\widehat{Q}_{a\to i}(\widehat{\nu})$	1RSB 腔消息或 SP 消息，函数到变量。
x	Parisi 的 1RSB 参数。
$\mathfrak{F}(x)$	对 BP 不动点计数的辅助模型自由熵密度。
$\Sigma(\phi)$	复杂度。
$\mathbb{F}^{\mathrm{RSB}}(Q)$	1RSB 腔自由熵，即辅助模型的 Bethe 自由熵，为消息的函数。
f^{RSB}	1RSB 腔自由熵密度。
y	零温 Parisi 参数，$y=\lim_{\beta\to\infty}\beta x$。
$\mathfrak{F}^e(y)$	对最小和不动点计数的辅助模型自由熵密度。
$\Sigma^e(e)$	能量复杂度。
$\mathbb{F}^{\mathrm{RSB},e}(Q)$	能量 1RSB 腔自由熵，即辅助模型 Bethe 自由熵，为消息的函数。
$f^{\mathrm{RSB},e}$	能量 1RSB 腔自由熵密度。

引文与书目差异说明

译者编排说明： A–D 与 E–F 的冻结草稿日期不同，正文和 Part F 书目有年份、拼写等差异。本译本保留它们。下列候选项仅供读者查找，不据同作者或相似题名猜定历史引文版本；年份不一致者不在正文强行建立单条对应。

- Gu、Purdom、Franco 和 Wah（2000）：正文 2000；PartF 同作者算法综述 1996；可查 Part F 候选条目，对应关系仍待核实。
- Cocco、Monasson、Montanari 和 Semerjian（2003）：正文 2003；PartF 同作者综述 2006；可查 Part F 候选条目，对应关系仍待核实。
- Achlioptas 和 Moore（2005）：正文 2005；PartF 相应 Two Moments 条目 2007；可查 Part F 候选条目，对应关系仍待核实。
- Richardson 和 Urbanke（2006）：正文 2006；PartF Modern Coding Theory 为 2008；可查 Part F 候选条目，对应关系仍待核实。
- Viana 和 Bray（1988）：正文 1988；PartF 稀释自旋玻璃条目 1985；可查 Part F 候选条目，对应关系仍待核实。
- Aldous 与 Fill，2005：正文 2005；PartF 筹备中专著标 2008；可查 Part F 候选条目，对应关系仍待核实。
- Macris（2005）：正文 2005；PartF EXIT 界条目 2007；可查 Part F 候选条目，对应关系仍待核实。
- Parisi（1998a）：正文 1998a；PartF 同题随机二分匹配猜想标 1998，链接到 Part F 相应条目。
- 专著（2006）：PartF 专著为 2008；可查 Part F 候选条目，对应关系仍待核实。
- 同作者，2004：SP 源码条目同作者 2004，链接到 Part F 相应条目。
- 正文 Gallavotti 与书目 Galavotti、Fischer 和 Hertz 与书目 Fischer 和 Hetz、McEliece 与书目 McEliecee 按上下文对应；两边拼写均保留。
- 第 2 章 Parisi（1998b）与 Part F 所列 Statistical Field Theory（1988）不一致；第 4 章 Krauth（1998）在 Part F 无同年份条目；第 11 章 Di、Richardson 和 Urbanke（2004）与 Part F 的作者组合/年份不能直接对应。这些引文不强行指定单条目标。

- 第 5 章 Mézard、Parisi 和 Virasoro（1985）在 Part F 分 1985a、1985b；第 6 章 Montanari（2001）在 Part F 分 2001a、2001b；第 15 章 Richardson 和 Urbanke（2001）在 Part F 分 2001a、b、c。缺后缀时不任选其一；可按本表作者顺序查阅候选条目。
- 部分历史年份和数表中的四位数字不是引文，不作为书目匹配。原书未给条目的历史人物/结果不补造文献。
- Part F 有四处原网址可见为空缺、空格或截缺，保留字串并注明；其余五个源网址做可点击入口，但未作联网可达性承诺。

参考文献

编排说明： 以下保留冻结 Part F 的全部书目及原题名、出版信息、未出版/私人通信等状态。源稿拼写、年代和正文引文可能不一致，未凭外部版本静默更新。正文作者–年份链接仅指向本表中的相应记录；无法唯一匹配者另列于交付说明。源网址保留为可点击入口，不声称当前仍可访问。

1. Aarts, E. H. L., Korst, J. H. M., and van Laarhoven, P. J. M. (2003). Simulated annealing. In Local search in combinatorial optimization, pp. 91–120. Princeton University Press.

2. Abou-Chacra, R., Anderson, P. W., and Thouless, D. J. (1973). A self-consistent theory of localization. J. Phys. C , 6, 1734–1752.

3. Achlioptas, D. (2001). Lower Bounds for Random 3-SAT via Differential Equations. Theoretical Computer Science, 265, 159–185.

4. Achlioptas, D. (2007). Private Communication.

5. Achlioptas, D. and Moore, C. (2004). The chromatic number of random regular graphs. In Proc. of RANDOM'04, Volume 3122 of Lecture Notes in Computer Science„ pp. 219–228. Springer Verlag.

6. Achlioptas, D. and Moore, C. (2007). Random k-SAT: Two Moments Suffice to Cross a Sharp Threshold. SIAM Journal of Computing, 36, 740–762.

7. Achlioptas, D. and Naor, A. (2005). The Two Possible Values of the Chromatic Number of a Random Graph. Annals of Mathematics, 162, 1333–1349.

8. Achlioptas, Dimitris, Naor, Assaf, and Peres, Y. (2005). Rigorous Location of Phase Transitions in Hard Optimization Problems. Nature, 435, 759–764.

9. Achlioptas, D. and Peres, Y. (2004). The Threshold for Random k-SAT is $2^k \log 2 - O(k)$. J. Amer. Math. Soc., 17, 947–973.

10. Achlioptas, D. and Ricci-Tersenghi, F. (2006). On the solution-space geometry of random constraint satisfaction problems. In Proc. of the 38th ACM Symposium on Theory of Computing, STOC, Seattle, WA, USA.

11. Aizenman, M., Sims, R., and Starr, S. L. (2005). Mean-Field Spin Glass models from the Cavity-ROSt Perspective. In Mathematical Physics of Spin Glasses, Cortona. Eprint arXiv:math-ph/0607060.

12. Aji, A., Jin, H., Khandekar, A., MacKay, D., and McEliece, R. (2001). BSC thresholds for code ensembles based on 'Typical Pairs' decoding. In Codes, Systems, and Graphical Models, IMA Volume in Mathematics and Its Applications, pp. 1–37. Springer.

13. Aji, S.M. and McEliece, R.J. (2000). The generalized distributive law. IEEE Trans. Inform. Theory, 46, 325–343.

14. Alava, M., Ardelius, J., Aurell, E., Kaski, P., Krishnamurthy, S., Orponen, P., and Seitz, S. (2007). Circumspect descent prevails in solving random constraint satisfaction problems. Eprint: arXiv:0711.4902.

15. Aldous, D. (1992). Asymptotics in the Random Assignment Problem. Probab. Th. Rel. Fields, 93, 507–534.

16. Aldous, D. (2001). The $\zeta(2)$ limit in the Random Assignment Problem. Rand. Struct. and Alg., 18, 381–418.

17. Aldous, D. and Bandyopadhyay, A. (2005). A survey of max-type recursive distributional equations. Annals Appl. Prob., 15, 1047–1110.

18. Aldous, D. and Fill, J. (2008). Reversible markov chains and random walks on graphs. Book in preparation. Available online at `http://www.stat.berkeley.edu/users/aldous/RWG/book.html`.

19. Aldous, D. and Steele, J. M. (2003). The Objective Method: Probabilistic Combinatorial Optimization and Local Weak Convergence. In Probability on discrete structures (ed. H. Kesten), pp. 1–72. Springer Verlag.

20. Altarelli, F., Monasson, R., and Zamponi, F. (2007). Relationship between clustering and algorithmic phase transitions in the random k-XORSAT model and its NP-complete extensions. J. Phys. A, 40, 867–886. Proc. of the International Workshop on Statistical-Mechanical Informatics, Kyoto.

21. Amraoui, A., Montanari, A., Richardson, T. J., and Urbanke, R. (2004). Finite-Length Scaling for Iteratively Decoded LDPC Ensembles. IEEE Trans. Inform. Theory.

22. Amraoui, A., Montanari, A., and Urbanke, R. (2007). How to Find Good Finite-Length Codes: From Art Towards Science. Eur. Trans. on Telecomms., 18, 491–508.

23. Applegate, D., Bixby, R., Chvátal, V., and Cook, W. The Traveling Salesman Problem. `http://www.tsp.gatech.edu/`.

24. Ardelius, J. and Aurell, E. (2006). Behavior of heuristics on large and hard satisfiability problems. Phys. Rev. E , 74, 037702.

25. Baldassi, C., Braunstein, A., Brunel, N., and Zecchina, R. (2007). Efficient supervised learning in networks with binary synapses. Proc. Natl. Acad. Sci., 1049, 11079–11084.

26. Balian, R. (1992). From Microphysics to Macrophysics: Methods and Applications of Statistical Physics. Springer-Verlag, New York.

27. Barg, A. (1998). Complexity Issues in Coding Theory. In Handbook of Coding Theory (ed. V. S. Pless and W. C. Huffman), Chapter 7. Elsevier Science, Amsterdam.

28. Barg, A. and Forney, G. D. (2002). Random Codes: Minimum Distances and Error Exponents. IEEE Trans. Inform. Theory, 48, 2568–2573.

29. Bauke, H. (2002). Statistische Mechanik des Zahlenaufteilungsproblems. Available at: `http://tina.nat.uni-magdeburg.de/heiko/Publications/index.php`.

30. Baxter, R. J. (1982). Exactly Solved Models in Statistical Mechanics. Academic Press, London.

31. Bayati, M., Shah, D., and Sharma, M. (2005). Maximum weight matching via max-product belief propagation. In Proc. of the IEEE Int. Symposium on Inform. Theory, Adelaide, pp. 1763–1767.

32. Bayati, M., Shah, D., and Sharma, M. (2006). A simpler max-product maximum weight matching algorithm and the auction algorithm. In Proc. of the IEEE Int. Symposium on Inform. Theory, Seattle, pp. 557–561.

33. Bender, E. A. and Canfield, E. R. (1978). The asymptotic number of labeled graphs with given degree sequence. J. Comb. Theory (A), 24, 296–307.

34. Berger, N., Kenyon, C., Mossel, E., and Peres, Y. (2005). Glauber dynamics on trees and hyperbolic graphs. Prob. Theor. Rel. Fields, 131, 311–340.

35. Berlekamp, E., McEliecee, R. J., and van Tilborg, H. C. A. (1978). On the inherent intractability of certain coding problems. IEEE Trans. Inform. Theory, 29, 384–386.

36. Berrou, C. and Glavieux, A. (1996). Near optimum error correcting coding and decoding: Turbo codes. IEEE Trans. Commun., 44, 1261–1271.

37. Bertsekas, D. P. (1988). The Auction Algorithm: A Distributed Relaxation Method for the Assignment Problem. Annals of Operations Research, 14, 105–123.

38. Bethe, H. A. (1935). Statistical theory of superlattices. Proc. Roy. Soc. London A, 150, 552–558.

39. Binder, K. and Young, A. P. (1986). Spin glasses. experimental facts, theoretical concepts, and open questions. Rev. Mod. Phys., 58, 801–976.

40. Biroli, G. and Mézard, M. (2002). Lattice Glass Models. Phys. Rev. Lett., 88, 025501.

41. Boettcher, S. (2003). Numerical Results for Ground States of Mean-Field Spin Glasses at low Connectivities. Phys. Rev. B , 67, 060403.

42. Bollobás, B. (1980). A probabilistic proof of an asymptotic formula for the number of labelled regular graphs. Eur. J. Combinatorics, 1, 296–307.

43. Bollobás, B. (2001). Random graphs. Cambridge University Press, Cambridge.

44. Bollobas, B., Borgs, C., Chayes, J. T., Kim, J. H., and Wilson, D. B. (2001). The scaling window of the 2-SAT transition. Rand. Struct. and Alg., 18, 201–256.

45. Borgs, C., Chayes, J., Mertens, S., and Pittel, B. (2003). Phase diagram for the constrained integer partitioning problem. Rand. Struct. Alg., 24, 315–380.

46. Borgs, C., Chayes, J., and Pittel, B. (2001). Phase transition and finite-size scaling for the integer partitioning problem. Rand. Struct. and Alg, 19, 247.

47. Bouchaud, J.-P. and Biroli, G. (2004). On the Adam-Gibbs-KirkpatrickThirumalai-Wolynes scenario for the viscosity increase in glasses. J. Chem. Phys, 121, 7347–7354.

48. Bouchaud, J.-P., Cugliandolo, L., Kurchan, J., and Mézard, M. (1997). Out of equilibrium dynamics in spin glasses and other glassy systems. In Recent progress in random magnets (ed. A. Young). World Scientific.

49. Bouchaud, J.-P. and Mézard, M. (1997). Universality classes for extreme value statistics. J. Phys. A: Math. Gen., 30, 7997–8015.

50. Bouchaud, J.-P., Mézard, M., and Dalibard, J. (ed.) (2007). Complex Systems: Lecture Notes of the Les Houches Summer School 2006. Elsevier, Amsterdam.

51. Bouchaud, J.-P. and Potters, M. (2003). Theory of Fiancial Risk and Derivative Pricing. Cambridge University Press, Cambridge.

52. Boyd, S. P. and Vandenberghe, L. (2004). Convex Optimization. Cambridge University Press, Cambridge.

53. Braunstein, A., Mézard, M., and Zecchina, R. (2004). C Code for the SP algorithm. Available online at: `http://www.ictp.trieste.it/zecchina/SP/`. **译注：** 源网址含空缺、空格或截缺；照录可见字串，不补造地址。

54. Braunstein, A., Mézard, M., and Zecchina, R. (2005). Survey propagation: an algorithm for satisfiability. Rand. Struct. and Alg., 27, 201–226.

55. Braunstein, A., Mulet, R., Pagnani, A., Weigt, M., and Zecchina, R. (2003). Polynomial iterative algorithms for coloring and analyzing random graphs. Phys. Rev. E , 68, 036702.

56. Braunstein, A. and Zecchina, R. (2004). Survey propagation as local equilibrium equations. J. Stat. Mech., 06007.

57. Burshtein, D., Krivelevich, M., Litsyn, S., and Miller, G. (2002). Upper Bounds on the Rate of LDPC Codes. IEEE Trans. Inform. Theory, 48, 2437–2449.

58. Burshtein, D. and Miller, G. (2004). Asymptotic Enumeration Methods for Analyzing LDPC Codes. IEEE Trans. Inform. Theory, 50, 1115–1131.

59. Caracciolo, S., Parisi, G., Patarnello, S., and Sourlas, N. (1990). 3d Ising Spin Glass in a Magnetic Field and Mean-Field Theory. Europhys. Lett., 11, 783.

60. Carlson, J. M., Chayes, J. T., Chayes, L., Sethna, J. P., and Thouless, D. J. (1990). Bethe lattice spin glass: The effects of a ferromagnetic bias and external fields. I. Bifurcation. J. Stat. Phys., 61, 987–1067.

61. Challet, D., Marsili, M., and Zhang, Y.-C. (2005). Minority Games. Oxford University Press, Oxford.

62. Chao, M.-T. and Franco, J. (1986). Probabilistic analysis of two heuristics for the 3-satisfiability problem. SIAM J. Comput , 15, 1106–1118.

63. Chao, M. T. and Franco, J. (1990). Probabilistic analysis of a generalization of the unit-clause literal selection heuristics for the k-satisfiability problem. Inform. Sci, 51, 289–314.

64. Chavas, J., Furtlehner, C., Mézard, M., and Zecchina, R. (2005). Survey-propagation decimation through distributed local computations. J. Stat. Mech., 11016.

65. Chayes, J. T., Chayes, L., Sethna, J. P., and Thouless, D. J. (1986). A mean field spin glass with short-range interactions. Commun. Math. Phys., 106, 41–89.

66. Chung, S.-Y., Forney, G. D., Richardson, T. J., and Urbanke, R. (2001). On the design of low-density parity-check codes within 0.0045 dB of the Shannon limit. IEEE Comm. Letters, 5, 58–60.

67. Chvátal, V. and Reed, B. (1992). Mick gets some (and the odds are on his side). In Proc. of the 33rd IEEE Symposium on Foundations of Computer Science, FOCS, Pittsburgh, pp. 620–627.

68. Ciliberti, S., Mézard, M., and Zecchina, R. (2005). Lossy Data Compression with Random Gates. Phys. Rev. Lett., 95, 038701.

69. Clifford, P. (1990). Markov random fields in statistics. In Disorder in physical systems: a volume in honour of John M. Hammersley (ed. G. Grimmett and D. Welsh), pp. 19–32. Oxford University Press.

70. Cocco, S., Dubois, O., Mandler, J., and Monasson, R. (2003). Rigorous Decimation-Based Construction of Ground Pure States for Spin-Glass Models on Random Lattices. Phys. Rev. Lett., 90, 047205.

71. Cocco, S. and Monasson, R. (2001a). Statistical physics analysis of the computational complexity of solving random satisfiability problems using backtrack algorithms. Eur. Phys. J. B , 22, 505–531.

72. Cocco, S. and Monasson, R. (2001b). Trajectories in phase diagrams, growth processes, and computational complexity: How search algorithms solve the 3-satisfiability problem. Phys. Rev. Lett., 86, 1654–1657.

73. Cocco, S., Monasson, R., Montanari, A., and Semerjian, G. (2006). Approximate analysis of search algorithms with physical methods. In Computational Complexity and Statistical Physics (ed. A. percus, G. Istrate, and C. Moore), Santa Fe Studies in the Science of Complexity, pp. 1–37. Oxford University Press.

74. Conway, J. H. and Sloane, N. J. A. (1998). Sphere Packings, Lattices and Groups. Springer Verlag, New York.

75. Cook, S. A. (1971). The complexity of theorem-proving procedures. In Proc. of the 3rd ACM Symposium on the Theory of Computing, STOC, Shaker Heights, OH, pp. 151–158.

76. Coolen, A.C.C., Kuehn, R., and Sollich, P. (2005). Theory of Neural Information Processing Systems. Oxford University Press, Oxford.

77. Cooper, G. F. (1990). The computational complexity of probabilistic inference using Bayesian belief networks. Artificial Intelligence, 42, 393–405.

78. Coppersmith, D. and Sorkin, G. B. (1999). Constructive bounds and exact expectations for the random assignment problem. Rand. Struct. and Alg., 15, 133–144.

79. Cover, T. M. and Thomas, J. A. (1991). Elements of Information Theory. John Wiley and sons, New York.

80. Creignou, N. and Daudé, H. (1999). Satisfiability threshold for random XOR-CNF formulas. Discr. Appl. Math., 96-97, 41–53.

81. Creignou, N., Daudé, H., and Dubois, O. (2003). Approximating the Satisfiability Threshold for Random k-XOR-formulas. Combinatorics, Probability and Computing, 12, 113–126.

82. Crisanti, A. and Leuzzi, L. (2007). Amorphous-amorphous transition and the two-step replica symmetry breaking phase. Phys. Rev. B , 76, 184417.

83. Csiszár, I. and Körner, J. (1981). Information Theory: Coding Theorems for Discrete Memoryless Systems. Academic Press, New York.

84. Dagum, P. and Luby, M. (1993). Approximating probabilistic inference in Bayesian belief networks is NP-hard. Artificial Intelligence, 60, 141–153.

85. Darling, R. W. R. and Norris, J. R. (2005). Structure of large random hypergraphs. Ann. Appl. Prob., 15, 125–152.

86. Daudé, H., Mézard, M., Mora, T., and Zecchina, R. (2008). Pairs of SAT assignments in random boolean formulae. Theor. Comp. Sci., 393, 260–279.

87. Davis, M., Logemann, G., and Loveland, D. (1962). A machine program for theorem-proving. Comm. ACM , 5, 394–397.

88. Davis, M. and Putnam, H. (1960). A computing procedure for quantification theory. J. Assoc. Comput. Mach., 7, 201–215.

89. de Almeida, J. R. L. and Thouless, D. (1978). Stability of the Sherrington-Kirkpatrick Solution of a Spin Glass Model. J.Phys.A, 11, 983–990.

90. de la Vega, W. F. (1992). On Random 2-SAT. Unpublished manuscript.

91. de la Vega, W. F. (2001). Random 2-SAT: results and problems. Theor. Comput. Sci., 265, 131–146.

92. Dembo, A. and Montanari, A. (2008a). Finite size scaling for the core of large random hypergraphs. Ann. Appl. Prob..

93. Dembo, A. and Montanari, A. (2008b). Graphical models, Bethe states and all that. In preparation.

94. Dembo, A. and Montanari, A. (2008c). Ising models on locally tree-like graphs. Eprint arxiv:0804.4726.

95. Dembo, A. and Zeitouni, O. (1998). Large Deviations Techniques and Applications. Springer-Verlag, New York.

96. Derrida, B. (1980). Random-energy model: Limit of a family of disordered models. Physical Review Letters, 45, 79.

97. Derrida, B. (1981). Random-energy model: An exactly solvable model of disordered systems. Physical Review B , 24, 2613–2626.

98. Derrida, B. (1985). A generalization of the random energy model which includes correlations between energies. J. Physique Lett., 46, L401–L407.

99. Derrida, B. and Gardner, E. (1986). Solution of the generalised random energy model. J. Phys. C , 19, 2253–2274.

100. Derrida, B. and Toulouse, G. (1985). Sample to sample fluctuations in the random energy model. J. Physique Lett., 46, L223–L228.

101. Di, C., Montanari, A., and Urbanke, R. (2004, June). Weight Distribution of LDPC Code Ensembles: Combinatorics Meets Statistical Physics. In Proc. of the IEEE Int. Symposium on Inform. Theory, Chicago, USA, pp. 102.

102. Di, C., Proietti, D., Richardson, T. J., Telatar, E., and Urbanke, R. (2002). Finite length analysis of low-density parity-check codes on the binary erasure channel. IEEE Trans. Inform. Theory, 48, 1570–1579.

103. Di, C., Richardson, T. J., and Urbanke, R. (2006). Weight Distribution of Low-Density Parity-Check Codes. IEEE Trans. Inform. Theory, 52, 4839–4855.

104. Diaconis, P. and Saloff-Coste, L. (1993). Comparison theorems for reversible Markov chains. Ann. Appl. Prob., 3, 696–730.

105. Diaconis, P. and Stroock, D. (1991). Geometric bounds for eigenvalues of Markov chains. Ann. Appl. Prob., 1, 36–61.

106. Dolecek, L., Zhang, Z., Anantharam, V., and Nikolić, B. (2007). Analysis of Absorbing Sets for Array-Based LDPC Codes. In Proc. of the IEEE Int. Conf. Communications, ICC, Glasgow, Scotland.

107. Dominicis, C. De and Mottishaw, P. (1987). Replica symmetry breaking in weak connectivity systems. J. Phys. A, 20, L1267–L1273.

108. Dorogotsev, S. N., Goltsev, A. V., and Mendes, J. F. F. (2002). Ising models on networks wth arbitrary distribution of connections. Phys. Rev. E , 66, 016104.

109. Dubois, O. and Boufkhad, Y. (1997). A general upper bound for the satisfiability threshold of random r-sat formulae. Journal of Algorithms, 24, 395–420.

110. Dubois, O. and Mandler, J. (2002). The 3-XORSAT Threshold. In Proc. of the 43rd IEEE Symposium on Foundations of Computer Science, FOCS, pp. 769–778.

111. Duchet, P. (1995). Hypergraphs. In Handbook of Combinatorics (ed. R. Graham, M. Grotschel, and L. Lovasz), pp. 381–432. MIT Press, Cambridge, MA.

112. Durrett, R. (1995). Probability: Theory and Examples. Duxbury Press, New York.

113. Edwards, S. F. and Anderson, P. W. (1975). Theory of spin glasses. J. Phys. F , 5, 965–974.

114. Elias, Peter (1955). Coding for two noisy channels. In Third London Symposium on Information Theory, pp. 61–76.

115. Ellis, R. S. (1985). Entropy, Large Deviations and Statistical Mechanics. Springer-Verlag, New York.

116. Erdös, P. and Rényi, A. (1960). On the evolution of random graphs. Publ. Math. Sci. Hung. Acad. Sci, 5, 17–61.

117. Euler, L. (1736). Solutio problematis ad geometriam situs pertinentis. Comment. Acad. Sci. U. Petrop., 8, 128–140. Reprinted in Opera Omnia Ser. I-7, pp. 1-10, 1766.

118. Evans, W., Kenyon, C., Peres, Y., and Schulman, L. J. (2000). Broadcasting on Trees and the Ising Model. Ann. Appl. Prob., 10, 410–433.

119. Feller, W. (1968). An Introduction to Probability Theory and its Applications. John Wiley and sons, New York.

120. Ferreira, F. F. and Fontanari, J. F. (1998). Probabilistic analysis of the number partitioning problem. J. Phys. A, 31, 3417–3428.

121. Fischer, K. H. and Hetz, J. A. (1993). Spin Glasses. Cambridge University Press, Cambridge.

122. Flajolet, P. and Sedgewick, R. (2008). Analytic Combinatorics. Cambridge University Press, Cambridge.

123. Forney, G. D. (2001). Codes on graphs: Normal realizations. IEEE Trans. Inform. Theory, 47, 520–548.

124. Forney, G. D. and Montanari, A. (2001). On exponential error bounds for random codes on the DMC. Available online at `http://www.stanford.edu/montanar/PAPERS/`. **译注：** 源网址含空缺、空格或截缺；照录可见字串，不补造地址。

125. Franco, J. (2000). Some interesting research directions in satisfiability. Annals of Mathematics and Artificial Intelligence, 28, 7–15.

126. Franz, S. and Leone, M. (2003). Replica Bounds for Optimization Problems and Diluted Spin Systems. J. Stat. Phys, 111, 535–564.

127. Franz, S., Leone, M., Montanari, A., and Ricci-Tersenghi, F. (2002). Dynamic phase transition for decoding algorithms. Phys. Rev. E , 22, 046120.

128. Franz, S., Leone, M., Ricci-Tersenghi, F., and Zecchina, R. (2001a). Exact Solutions for Diluted Spin Glasses and Optimization Problems. Phys. Rev. Lett., 87, 127209.

129. Franz, S., Leone, M., and Toninelli, F. (2003). Replica bounds for diluted non-Poissonian spin systems. J. Phys. A, 36, 10967–10985.

130. Franz, S., Mézard, M., Ricci-Tersenghi, F., Weigt, M., and Zecchina, R. (2001b). A ferromagnet with a glass transition. Europhys. Lett., 55, 465.

131. Franz, S. and Parisi, G. (1995). Recipes for Metastable States in Spin Glasses. J. Physique I , 5, 1401.

132. Friedgut, E. (1999). Sharp thresholds of graph proprties, and the k-sat problem. J. Amer. Math. Soc., 12, 1017–1054.

133. Friedman, N., Linial, M., Nachman, I., and Peér, D. (2000). Using bayesian networks to analyze expression data. J. Comp. Bio., 7, 601–620.

134. Galavotti, G. (1999). Statistical Mechanics: A Short Treatise. Springer Verlag, New York.

135. Gallager, R. G. (1962). Low-density parity-check codes. IEEE Trans. Inform. Theory, 8, 21–28.

136. Gallager, R. G. (1963). Low-Density Parity-Check Codes. MIT Press, Cambridge, Massachussetts. Available online at `http://web./gallager/www/pages/ldpc.pdf`. **译注：** 源网址含空缺、空格或截缺；照录可见字串，不补造地址。

137. Gallager, R. G. (1965). A simple derivation of the coding theorem and some applications. IEEE Trans. Inform. Theory, IT-11, 3–18.

138. Gallager, R. G. (1968). Information Theory and Reliable Communication. John Wiley and sons, New York.

139. Gardner, E. (1985). Spin glasses with p-spin interactions. Nuclear Physics B , 257, 747–765.

140. Garey, M. R. and Johnson, D. S. (1979). Computers and Intractability: A Guide to the Theory of NP-Completeness. W. H. Freeman & Co., New York.

141. Garey, M. R., Johnson, D. S., and Stockmeyer, L. (1976). Some simplified NP-complete graph problems. Theoretical Computer Science, 1, 237–267.

142. Gent, I. P. and Walsh, T. (1998). Analysis of heuristics for number partitioning. Computational Intelligence, 14(3), 430–451.

143. Georgii, H.-O. (1988). Gibbs Measures and Phase Transitions. Walter de Gruyter, Berlin - New York.

144. Gerschenfeld, A. and Montanari, A. (2007). Reconstruction for models on random graph. In Proc. of the 48th IEEE Symposium on Foundations of Computer Science, FOCS, Providence, USA, pp. 194–205.

145. Goerdt, A. (1996). A threshold for unsatisfiability. J. Comput. System Sci., 53, 469–486.

146. Goldschmidt, Y. Y. (1991). Spin glass on the finite-connectivity lattice: The replica solution without replicas. Phys. Rev. B , 43, 8148–8152.

147. Goldschmidt, Y. Y. and Dominicis, C. De (1990). Replica symmetry breaking in the spin-glass model on lattices with finite connectivity: Application to graph partitioning. Phys. Rev. B , 41, 2184–2197.

148. Goldschmidt, Y. Y. and Lai, P. Y. (1990). The finite connectivity spin glass: investigation of replica symmetry breaking of the ground state. J. Phys. A, 23, L775–L782.

149. Gomes, C. P. and Selman, B. (2005). Can get satisfaction. Nature, 435, 751–752.

150. Gross, D. J. and Mézard, M. (1984). The simplest spin glass. Nuclear Physics, B240[FS12], 431–452.

151. Grosso, C. (2004). Cavity method analysis for random assignment problems. Tesi di Laurea, Università degli Studi di Milano.

152. Gu, J., Purdom, P. W., Franco, J., and Wah, B. W. (1996). Algorithms for the Satisfiability (SAT) Problem: A Survey. In Satisfiability Problem:Theory and Applications (ed. D. Du, J. Gu, and P. M. Pardalos), pp. 19–151. Amer. Math. Soc.

153. Guerra, F. (2003). Broken Replica Symmetry Bounds in the Mean Field Spin Glass Model. Commun. Math. Phys., 233, 1–12.

154. Guerra, F. (2005). Spin glasses. Eprint: arXiv:cond-mat/0507581 .

155. Guo, D. and Verdú, S. (2002). Multiuser detection and statistical mechanics. In Communications Information and Network Security (ed. V. Bhargava, H. Poor, V. Tarokh, and S. Yoon), Volume Ch 13, pp. 229–277. Kluwer Academic Publishers.

156. Hartmann, A.K. and Weigt, M. (2005). Phase Transitions in Combinatorial Optimization Problems. Wiley-VCH, Weinheim, Deutschland.

157. Hartmann, A. K. and Rieger, H. (ed.) (2002). Optimization Algorithms in Physics. Wiley-VCH, Berlin.

158. Hartmann, A. K. and Rieger, H. (2004). New Optimization Algorithms in Physics. Wiley-VCH, Berlin.

159. Hayes, B. (2002). The Easiest Hard Problem. American Scientist , 90(2), 113–117.

160. Henley, C. L. (1986). Ising domain growth barriers on a Cayley tree at percolation. Phys. Rev. B , 33, 7675–7682.

161. Huang, K. (1987). Statistical Mechanics. John Wiley and sons, New York.

162. Janson, S., Luczak, T., and Ruciński, A. (2000). Random graphs. John Wiley and sons, New York.

163. Jaynes, E. T. (1957). Information Theory and Statistical Mechanics. Phys. Rev., 106, 620–630.

164. Jensen, F. V. (ed.) (1996). An introduction to Bayesian networks. UCL Press, London.

165. Jerrum, M. and Sinclair, A. (1996). The Markov chain Monte Carlo method: an approach to approximate counting and integration. In Approximation Algorithms for NP-hard Problems, pp. 482–520. PWS Publishing.

166. Johnston, D. A. and Plechác, P. (1998). Equivalence of ferromagnetic spin models on trees and random graphs. J. Phys. A, 31, 475–482.

167. Jordan, M. (ed.) (1998). Learning in graphical models. MIT Press, Boston.

168. Kabashima, Y., Murayama, T., and Saad, D. (2000a). Typical Performance of Gallager-Type Error-Correcting Codes. Phys. Rev. Lett., 84, 1355–1358.

169. Kabashima, Y., Murayama, T., Saad, D., and Vicente, R. (2000b). Regular and Irregular Gallager-type Error Correcting Codes. In Advances in Neural Information Processing Systems 12 (ed. S. A. S. et al.). MIT press, Cambridge, MA.

170. Kabashima, Y. and Saad, D. (1998). Belief propagation vs. TAP for decoding corrupted messages. Europhys. Lett , 44, 668–674.

171. Kabashima, Y. and Saad, D. (1999). Statistical Mechanics of Error Correcting Codes. Europhys. Lett., 45, 97–103.

172. Kabashima, Y. and Saad, D. (2000). Error-correcting Code on a Cactus: a solvable Model. Europhys. Lett., 51, 698–704.

173. Kanter, I. and Sompolinsky, H. (1987). Mean Field Theory of Spin-Glasses with Finite Coordination Number. Phys. Rev. Lett., 58, 164–167.

174. Karmarkar, N. and Karp, R.M. (1982). The differencing method of set partitioning. Technical Report CSD 82/113, Technical Report University of California Berkeley.

175. Karmarkar, N., Karp, R. M., Lueker, G. S., and Odlyzko, A. M. (1986). Probabilistic analysis of optimum partitioning. J. Appl. Prob., 23, 626–645.

176. Karoński, M. and Luczak, T. (2002). The phase transition in a random hypergraph. Journal of Computational and Applied Mathematics, 142, 125–135.

177. Karp, R.M. (1987). An upper bound on the expected cost of an optimal assignment. In Proc. of the Japan-U.-S. Joint Seminar, New York, USA. Academic Press.

178. Katsura, S., Inawashiro, S., and Fujiki, S. (1979). Spin glasses for the infinitely long ranged bond Ising model without the use of the replica method. Physica, 99 A, 193–216.

179. Kelly, F. P. (1991). Network routing. Phil. Trans. R. Soc. London A, 337, 343–367.

180. Kikuchi, R. (1951). A theory of cooperative phenomena. Phys. Rev., 81, 988–1003.

181. Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P. (1983). Optimization by Simulated Annealing. Science, 220, 671–680.

182. Kirkpatrick, S. and Selman, B. (1994). Critical behavior in the satisfiability of random boolean expressions. Science, 264, 1297–1301.

183. Kirkpatrick, S. and Sherrington, D. (1978). Infinite ranged models of spin glasses. Phys. Rev. B , 17, 4384–4403.

184. Kirkpatrick, T. R. and Thirumalai, D. (1987). p-spin interaction spin glass models: connections with the structural glass problem. Phys. Rev. B , 36, 5388–5397.

185. Kirkpatrick, T. R. and Wolynes, P. G. (1987). Connections between some kinetic and equilibrium theories of the glass transition. Phys. Rev. A, 35, 3072–3080.

186. Kirousis, L. M., Kranakis, E., Krizanc, D., and Stamatiou, Y. (1998). Approximating the unsatisfiability threshold of random formulas. Rand. Struct. and Alg., 12, 253–269.

187. Klein, M. W., Schowalter, L. J., and Shukla, P. (1979). Spin glasses in the Bethe-Peierls-Weiss and other mean field approximations. Phys. Rev. B , 19, 1492–1502.

188. Kleinberg, J. M., Kumar, R., Raghavan, P., Rajagopalan, S., and Tomkins, A. S. (1999, July). The Web as a Graph: Measurements, Models, and Methods. In 5th Conference on Computing and Combinatorics, Tokyo, pp. 1–17.

189. Korf, R. E. (1998). A complete anytime algorithm for number partitioning. Artificial Intelligence, 106, 181:203.

190. Kötter, R. and Vontobel, P. O. (2003). Graph covers and iterative decoding of finite-length codes. In Proc. 3rd Int. Conf. on Turbo Codes and Related Topics, Brest, France, pp. 75–82.

191. Krauth, W. (2006). Statistical Mechanics: Algorithms and Computations. Oxford University Press, Oxford.

192. Krauth, W. and Mézard, M. (1989). The cavity method and the Traveling Salesman Problem. Europhys. Lett., 8, 213–218.

193. Krzakala, F., Montanari, A., Ricci-Tersenghi, F., Semerjian, G., and Zdeborova, L. (2007). Gibbs states and the set of solutions of random constraint satisfaction problems. Proc. Natl. Acad. Sci., 104, 10318–10323.

194. Krzakala, F. and Zdeborova, L. (2007). Phase Transitions in the Coloring of Random Graphs. Phys. Rev. E , 76, 031131.

195. Kschischang, F. R., Frey, B. J., and Loeliger, H.-A. (2001). Factor graphs and the sum-product algorithm. IEEE Trans. Inform. Theory, 47, 498–519.

196. Lauritzen, S. L. (1996). Graphical Models. Oxford University Press, Oxford.

197. Leone, M., Ricci-Tersenghi, F., and Zecchina, R. (2001). Phase coexistence and finite-size scaling in random combinatorial problems. J. Phys. A, 34, 4615–4626.

198. Leone, M., Vázquez, A., Vespignani, A., and Zecchina, R. (2004). Ferromagnetic ordering in graphs with arbitrary degree distribution. Eur. Phys. J. B , 28, 191–197.

199. Linusson, S. and Wästlund, J. (2004). A proof of Parisi's conjecture on the random assignment problem. Prob. Theory Relat. Fields, 128, 419–440.

200. Litsyn, S. and Shevelev, V. (2003). Distance distributions in ensembles of irregular low-density parity-check codes. IEEE Trans. Inform. Theory, 49, 3140–3159.

201. Luby, M., Mitzenmacher, M., Shokrollahi, A., and Spielman, D. A. (1998). Analysis of low density codes and improved designs using irregular graphs. In Proc. of the 30th ACM Symposium on Theory of Computing, STOC, pp. 249–258.

202. Luby, M., Mitzenmacher, M., Shokrollahi, A., and Spielman, D. A. (2001a). Efficient erasure correcting codes. IEEE Trans. Inform. Theory, 47(2), 569–584.

203. Luby, M., Mitzenmacher, M., Shokrollahi, A., and Spielman, D. A. (2001b). Improved low-density parity-check codes using irregular graphs. IEEE Trans. Inform. Theory, 47, 585–598.

204. Luby, M., Mitzenmacher, M., Shokrollahi, A., Spielman, D. A., and Stemann, V. (1997). Practical loss-resilient codes. In Proc. of the 29th ACM Symposium on Theory of Computing, STOC, pp. 150–159.

205. Ma, S.-K. (1985). Statistical Mechanics. World Scientific, Singapore.

206. MacKay, D. J. C. (1999). Good Error Correcting Codes Based on Very Sparse Matrices. IEEE Trans. Inform. Theory, 45, 399–431.

207. MacKay, D. J. C. (2002). Information Theory, Inference & Learning Algorithms. Cambridge University Press, Cambridge.

208. MacKay, D. J. C. and Neal, R. M. (1996). Near Shannon Limit Performance of Low Density Parity Check Codes. Electronic Lett., 32, 1645–1646.

209. MacKay, D. J. C. and Postol, M. S. (2003). Weaknesses of Margulis and Ramanujan-Margulis Low-Density Parity-Check Codes. Elect. Notes in Theor. Computer Sci., 74, 97–104.

210. Macris, N. (2007). Sharp bounds on generalised EXIT function. IEEE Trans. Inform. Theory, 53, 2365–2375.

211. Maneva, E., Mossel, E., and Wainwright, M. J. (2005). A new look at survey propagation and its generalizations. In Proc. of the 16th ACM-SIAM Symposium on Discrete Algorithms, SODA, Vancouver, pp. 1089–1098.

212. Marinari, E., Parisi, G., and Ruiz-Lorenzo, J. (1997). Numerical simulations of spin glass systems. In Spin Glasses and Random Fields (ed. A. Young). World Scientific.

213. Martin, O. C., Mézard, M., and Rivoire, O. (2005). Random multi-index matching problems. J. Stat. Mech., 09006.

214. Martinelli, F. (1999). Lectures on glauber dynamics for discrete spin models. In Lectures on probability theory and statistics, Saint-Flour 1997, Lecture Notes in Mathematics, pp. 93–191. Springer.

215. Martinelli, F., Sinclair, A., and Weitz, D. (2004). Glauber Dynamics on Trees: Boundary Conditions and Mixing Time. Commun. Math. Phys, 250, 301–334.

216. McEliece, R. J., MacKay, D. J. C., and Cheng, J.-F. (1998). Turbo decoding as an instance of Pearl's "belief propagation" algorithm. IEEE Jour. on Selected Areas in Communications, 16, 140–152.

217. Méasson, C., Montanari, A., Richardson, T., and Urbanke, R. (2005b). The Generalized Area Theorem and Some of its Consequences. submitted.

218. Méasson, C., Montanari, A., and Urbanke, R. (2005a). Maxwell Construction: The Hidden Bridge between Iterative and Maximum a Posteriori Decoding. IEEE Trans. Inform. Theory. accepted.

219. Mertens, S. (1998). Phase transition in the number partitioning problem. Phys. Rev. Lett., 81(20), 4281–4284.

220. Mertens, S. (2000). Random costs in combinatorial optimization. Phys. Rev. Lett., 84(7), 1347–1350.

221. Mertens, S. (2001). A physicist's approach to number partitioning. Theor. Comp. Science, 265, 79–108.

222. Mertens, S., Mézard, M., and Zecchina, R. (2006). Threshold values of Random K-SAT from the cavity method. Rand. Struct. and Alg., 28, 340–37.

223. Mézard, M. and Montanari, A. (2006). Reconstruction on trees and spin glass transition. J. Stat. Phys., 124, 1317–1350.

224. Mézard, M., Mora, T., and Zecchina, R. (2005a). Clustering of Solutions in the Random Satisfiability Problem. Phys. Rev. Lett., 94, 197205.

225. Mézard, M., Palassini, M., and Rivoire, O. (2005b). Landscape of Solutions in Constraint Satisfaction Problems. Phys. Rev. Lett., 95, 200202.

226. Mézard, M. and Parisi, G. (1985). Replicas and Optimization. J. Physique Lett., 46, L771–L778.

227. Mézard, M. and Parisi, G. (1986). Mean-Field Equations for the Matching and the Traveling Salesman Problems. Europhys. Lett., 2, 913–918.

228. Mézard, M. and Parisi, G. (1987). Mean-Field Theory of Randomly Frustrated Systems with Finite Connectivity. Europhys. Lett., 3, 1067–1074.

229. Mézard, M. and Parisi, G. (1999). Thermodynamics of glasses: a first principles computation. Phys. Rev. Lett., 82, 747–751.

230. Mézard, M. and Parisi, G. (2001). The Bethe lattice spin glass revisited. Eur. Phys. J. B , 20, 217–233.

231. Mézard, M. and Parisi, G. (2003). The Cavity Method at Zero Temperature. J. Stat. Phys., 111, 1–34.

232. Mézard, M., Parisi, G., Sourlas, N., Toulouse, G., and Virasoro, M. A. (1985). Replica symmetry breaking and the nature of the spin glass phase. J. Physique, 45, 843–854.

233. Mézard, M., Parisi, G., and Virasoro, M. A. (1985a). Random free energies in spin glasses. J. Physique Lett., 46, L217–L222.

234. Mézard, M., Parisi, G., and Virasoro, M. A. (1985b). SK model: the replica solution without replicas. Europhys. Lett., 1, 77–82.

235. Mézard, M., Parisi, G., and Virasoro, M. A. (1987). Spin Glass Theory and Beyond. World Scientific, Singapore.

236. Mézard, M., Parisi, G., and Zecchina, R. (2003). Analytic and Algorithmic Solution of Random Satisfiability Problems. Science, 297, 812–815.

237. Mézard, M., Ricci-Tersenghi, F., and Zecchina, R. (2003). Two solutions to diluted p-spin models and XORSAT problems. J. Stat. Phys., 111, 505–533.

238. Mézard, M., Tarzia, M., and Toninelli, C. (2007). Statistical physics of group testing. J. Phys. A, 40, 12019–12029. Proc. of the International Workshop on Statistical-Mechanical Informatics, Kyoto.

239. Mézard, M. and Zecchina, R. (2002). The random K-satisfiability problem: from an analytic solution to an efficient algorithm. Phys. Rev. E , 66, 056126.

240. Migliorini, G. and Saad, D. (2006). Finite-connectivity spin-glass phase diagrams and low-density parity check codes. Phys. Rev. E , 73, 026122.

241. Molloy, M. and Reed, B. (1995). A critical point for random graphs with a given degree sequence. Rand. Struct. and Alg., 6, 161–180.

242. Monasson, R. (1995). Structural glass transition and the entropy of metastable states. Phys. Rev. Lett., 75, 2847–2850.

243. Monasson, R. (1998). Optimization problems and replica symmetry breaking in finite connectivity spin glasses. J. Phys. A, 31, 513–529.

244. Monasson, R. and Zecchina, R. (1996). Entropy of the K-satisfiability problem. Phys. Rev. Lett., 76, 3881–3885.

245. Monasson, R. and Zecchina, R. (1998). Tricritical points in random combinatorics: the (2 + p)-sat case. J. Phys. A, 31, 9209–9217.

246. Monasson, R., Zecchina, R., Kirkpatrick, S., Selman, B., and Troyansky, L. (1999). Determining computational complexity from characteristic phase transitions. Nature, 400, 133–137.

247. Monod, P. and Bouchiat, H. (1982). Equilibrium magnetization of a spin glass: is mean-field theory valid? J. Physique Lett., 43, 45–54.

248. Montanari, Andrea (2000). Turbo codes: the phase transition. Eur. Phys. J. B , 18, 121–136.

249. Montanari, A. (2001a). Finite Size Scaling and Metastable States of Good Codes. In Proc. of the 39th Allerton Conference on Communications, Control and Computing, Monticello, IL.

250. Montanari, A. (2001b). The glassy phase of Gallager codes. Eur. Phys. J. B , 23, 121–136.

251. Montanari, A. (2003). 2RSB Population Dynamics for Spin Glasses. Unpublished.

252. Montanari, A. (2005). Tight bounds for LDPC and LDGM codes under MAP decoding. IEEE Trans. Inform. Theory, 51, 3221–3246.

253. Montanari, A., Parisi, G., and Ricci-Tersenghi, F. (2004). Instability of one-step replica-symmetry breaking in satisfiability problems. J. Phys. A, 37, 2073–2091.

254. Montanari, A. and Ricci-Tersenghi, F. (2003). On the nature of the low-temperature phase in discontinuous mean-field spin glasses. Eur. Phys. J. B , 33, 339–346.

255. Montanari, A. and Ricci-Tersenghi, F. (2004). Cooling-schedule dependence of the dynamics of mean-field glasses. Phys. Rev. B , 70, 134406.

256. Montanari, A., Ricci-Tersenghi, F., and Semerjian, G. (2007). Solving Constraint Satisfaction Problems through Belief Propagation-guided decimation. In Proc. of the 45th Allerton Conference on Communications, Control and Computing, Monticello, IL.

257. Montanari, A., Ricci-Tersenghi, F., and Semerjian, G. (2008). Cluster of Solutions and Replica Symmetry Breaking in Random k-satisfiability. J. Stat. Mech., 04004.

258. Montanari, A. and Semerjian, G. (2005). From Large Scale Rearrangements to Mode Coupling Phenomenology in Model Glasses. Phys. Rev. Lett., 94, 247201.

259. Montanari, A. and Semerjian, G. (2006a). On the Dynamics of the Glass Transition on Bethe Lattices. J. Stat. Phys., 124, 103–189.

260. Montanari, A. and Semerjian, G. (2006b). Rigorous Inequalities Between Length and Time Scales in Glassy Systems. J. Stat. Phys., 125, 23–54.

261. Montanari, A. and Shah, D. (2007). Counting Good Truth Assignmants for Random Satisfiability Formulae. In Proc. of the 18th Symposium of Discrete Algorithms, SODA, New Orleans, USA, pp. 1255–1265.

262. Montanari, A. and Sourlas, N. (2000). The statistical mechanics of turbo codes. Eur. Phys. J. B , 18, 107–119.

263. Mooij, J. M. and Kappen, H. K. (2005). On the properties of Bethe aproximation and loopy belief propagation on binary networks. J. Stat. Mech., 11012.

264. Mora, T. and Mézard, M. (2006). Geometrical organization of solutions to random linear Boolean equations. J. Stat. Mech., 10007.

265. Mora, T. and Zdeborová, L. (2007). Random subcubes as a toy model for constraint satisfaction problems. Eprint arXiv:0710.3804.

266. Morita, T. (1979). Variational principle for the distribution function of the effective field for the random Ising model in the Bethe approximation. Physica, 98 A, 566–572.

267. Mossel, E. (2003). Phase Tranditions in Phylogeny. Trans. of Amer. Math. Soc., 356, 2379–2404.

268. Mossel, E. (2004). Survey: Information flow on trees. In Graphs, Morphisms, and Statistical Physics, pp. 155–170. American Mathematical Society.

269. Mossel, E. and Peres, Y. (2003). Information flow on trees. Ann. Appl. Prob., 13, 817–844.

270. Mottishaw, P. and Dominicis, C. De (1987). On the stability of randomly frustrated systems with finite connectivity. J. Phys. A, 20, L375–L379.

271. Mulet, R., Pagnani, A., Weigt, M., and Zecchina, R. (2002). Coloring Random Graphs. Phys. Rev. Lett., 89, 268701.

272. Nair, C., Prabhakar, B., and Sharma, M. (2003). Proofs of the Parisi and Coppersmith-Sorkin conjectures for the finite random assignment problem. In Proc. of the 44th IEEE Symposium on Foundations of Computer Science, FOCS, pp. 168–178.

273. Nair, C., Prabhakar, B., and Sharma, M. (2006). Proofs of the Parisi and Coppersmith-Sorkin random assignment conjectures. Rand. Struct. and Alg., 27, 413–444.

274. Nakamura, K., Kabashima, Y., and Saad, D. (2001). Statistical Mechanics of Low-Density Parity Check Error-Correcting Codes over Galois Fields. Europhys. Lett., 56, 610–616.

275. Nakanishi, K. (1981). Two- and three-spin cluster theory of spin glasses. Phys. Rev. B , 23, 3514–3522.

276. Neri, I., Skantzos, N. S., and Bollé, D. (2008). Gallager error correcting codes for binary asymmetric channels. Eprint arXiv:0803.2580.

277. Nishimori, H. (2001). Statistical Physics of Spin Glasses and Information Processing. Oxford University Press, Oxford.

278. Norris, J. R. (1997). Markov Chains. Cambridge University Press, Cambridge, UK.

279. Panchenko, D. and Talagrand, M. (2004). Bounds for diluted mean-fields spin glass models. Probab. Theor. Relat. Fields, 130, 319–336.

280. Papadimitriou, C. H. (1991). On selecting a satisfying truth assignment. In Proc. of the 32nd IEEE Symposium on Foundations of Computer Science, FOCS, pp. 163–169.

281. Papadimitriou, C. H. (1994). Computational Complexity. Addison Wesley, Reading, MA.

282. Papadimitriou, C. H. and Steiglitz, K. (1998). Combinatorial Optimization. Dover Publications, Mineola, New York.

283. Parisi, G. (1979). Toward a mean field theory for spin glasses. Phys. Lett., 73 A, 203–205.

284. Parisi, G. (1980a). A Sequence of Approximated Solutions to the SK model for Spin Glasses. J. Phys. A, 13, L115–L121.

285. Parisi, G. (1980b). The order parameter for spin glasses: A function on the interval [0, 1]. J. Phys. A, 13, 1101–1112.

286. Parisi, G. (1983). Order parameter for spin glasses. Phys. Rev. Lett., 50, 1946–1948.

287. Parisi, G. (1988). Statistical Field Theory. Addison Wesley, Reading, MA.

288. Parisi, G. (1998). A conjecture on random bipartite matching. Eprint: arXiv:cond-mat/9801176.

289. Parisi, G. (2002). On local equilibrium equations for clustering states. Eprint: arXiv:cs/0212047v1.

290. Parisi, G. (2003). A backtracking survey propagation algorithm for K-satisfiability. Eprint arxiv:cond-mat/0308510.

291. Pearl, J. (1988). Probabilistic reasoning in intelligent systems: networks of plausible inference. Morgan Kaufmann, San Francisco.

292. Pitman, J. and Yor, M. (1997). The two-parameter Poisson-Dirichlet distribution derived from a stable subordinator. Ann. Prob., 25, 855–900.

293. Prim, R. C. (1957). Shortest connection networks and some generalizations. Bell Sys. Tech. Journal , 36, 1389–1401.

294. Pumphrey, S. J. (2001). Solving the Satisfiability Problem Using Message Passing Techniques. Cambridge Physics Project Report.

295. Reif, F. (1965). Fundamentals of statistical and thermal physics. McGraw-Hill, New York.

296. Ricci-Tersenghi, F., Weigt, M., and Zecchina, R. (2001). Exact Solutions for Diluted Spin Glasses and Optimization Problems. Phys. Rev. E , 63, 026702.

297. Richardson, T. and Urbanke, R. (2001a). An introduction to the analysis of iterative coding systems. In Codes, Systems, and Graphical Models, IMA Volume in Mathematics and Its Applications, pp. 1–37. Springer.

298. Richardson, T. J. (2003). Error floors of LDPC codes. In Proc. of the 41st Allerton Conference on Communications, Control and Computing, Monticello, IL.

299. Richardson, T. J., Shokrollahi, A., and Urbanke, R. (2001). Design of capacity-approaching irregular low-density parity-check codes. IEEE Trans. Inform. Theory, 47, 610–637.

300. Richardson, T. J. and Urbanke, R. (2001b). The capacity of low-density parity check codes under message-passing decoding. IEEE Trans. Inform. Theory, 47, 599–618.

301. Richardson, T. J. and Urbanke, R. (2001c). Efficient encoding of low-density parity-check codes. IEEE Trans. Inform. Theory, 47, 638–656.

302. Richardson, T. J. and Urbanke, R. (2008). Modern Coding Theory. Cambridge University Press, Cambridge. Available online at `http://lthcwww.epfl.ch/mct/index.php`.

303. Rivoire, O., Biroli, G., Martin, O. C., and Mézard, M. (2003). Glass models on Bethe lattices. Eur. Phys. J. B , 37, 55–78.

304. Ruelle, D. (1987). A mathematical reformulation of Derrida's REM and GREM. Comm. Math. Phys., 108, 225–239.

305. Ruelle, D. (1999). Statistical Mechanics: Rigorous Results. World Scientific Publishing, Singapore.

306. Rujan, P. (1993). Finite temperature error-correcting codes. Phys. Rev. Lett., 70, 2968–2971.

307. Schmidt-Pruzan, J. and Shamir, E. (1985). Component structure in the evolution of random hypergraphs. Combinatorica, 5, 81–94.

308. Schöning, U. (1999). A Probabilistic algorithm for k-SAT and constraint satisfaction problems. In Proc. of the 40th IEEE Symposium on Foundations of Computer Science, FOCS, New York, pp. 410–414.

309. Schöning, U. (2002). A Probabilistic Algorithm for k-SAT Based on Limited Local Search and Restart. Algorithmica, 32, 615–623.

310. Selman, B. and Kautz, H. A. (1993). Domain independent extensions to gsat: Solving large structural satisfiability problems. In Proc. IJCAI-93, Chambery, France.

311. Selman, B., Kautz, H. A., and Cohen, B. (1994). Noise strategies for improving local search. In Proc. of AAAI-94, Seattle, WA.

312. Selman, B. and Kirkpatrick, S. (1996). Critical behavior in the computational cost of satisfiability testing. Artificial Intelligence, 81, 273–295.

313. Selman, B., Mitchell, D., and Levesque, H. (1996). Generating hard satisfiability problems. Artificial Intelligence, 81, 17–29.

314. Shannon, C. E. (1948). A mathematical theory of communication. Bell Sys. Tech. Journal , 27, 379–423, 623–655. Available electronically at `http://cm.bell-labs.com/cm/ms/what/shannonday/paper.html`.

315. Sherrington, D. and Kirkpatrick, S. (1975). Solvable model of a spin glass. Phys. Rev. Lett., 35, 1792–1796.

316. Shohat, J. A. and Tamarkin, J. D. (1943). The Problem of Moments. Math. Surveys No. 1, Amer. Math. Soc., New York.

317. Sinclair, A. (1997). Convergence rates for Monte Carlo experiments. In Numerical Methods for Polymeric Systems, IMA Volumes in Mathematics and its Applications, pp. 1–18. Springer.

318. Sipser, M. and Spielman, D. A. (1996). Expander Codes. IEEE Trans. Inform. Theory, 42, 1710–1722.

319. Sokal, A. D. (1996). Monte Carlo Methods in Statistical Mechanics: Foundations and New Algorithms. In Lectures at the Cargèse Summer School on 'Functional Integration: Basics and Applications'. Available online at `http://www.math.nyu.edu/faculty/goodman/teaching/MonteCarlo/montecarlo.html`. **译注：**源网址含空缺、空格或截缺；照录可见字串，不补造地址。

320. Sourlas, N. (1989). Spin-glass models as error-correcting codes. Nature, 339, 693.

321. Spielman, D. A. (1997). The complexity of error-correcting codes. In Lecture Notes in Computer Science 1279, pp. 67–84.

322. Sportiello, A. (2004). Private communication.

323. Stepanov, M. G., Chernyak, V. Y., Chertkov, M., and Vasic, B. (2005). Diagnosis of weaknesses in modern error correction codes: a physics approach. Phys. Rev. Lett., 95, 228701–228704.

324. Svenson, P. and Nordahl, M. G. (1999). Relaxation in graph coloring and satisfiability problems. Phys. Rev. E , 59, 3983–3999.

325. Talagrand, M. (2000). Rigorous low temperature results for the mean field p-spin interaction model. Probab. Theor. Relat. Fields, 117, 303–360.

326. Talagrand, M. (2003). Spin Glasses: A Challenge for Mathematicians. Springer-Verlag, Berlin.

327. Tanaka, T. (2002). A statistical-mechanics approach to large-system analysis of cdma multiuser detectors. IEEE Trans. Inform. Theory, 48, 2888–2910.

328. Tanner, R.M. (1981). A recursive approach to low complexity codes. IEEE Trans. Inform. Theory, 27, 533–547.

329. Thouless, D. J. (1986). Spin-Glass on a Bethe Lattice. Phys. Rev. Lett., 6, 1082–1085.

330. Thouless, D. J., Anderson, P. W., and Palmer, R. G. (1977). Solution of 'Solvable model of a spin glass'. Phil. Mag., 35, 593–601.

331. Toulouse, G. (1977). Theory of the frustration effect in spin glasses: I. Communications on Physics, 2, 115–119.

332. Viana, L and Bray, A. J. (1985). Phase diagrams for dilute spin glasses. J. Phys. C , 18, 3037–3051.

333. Wainwright, M. J., Jaakkola, T. S., and Willsky, A. S. (2005a). A New Class of Upper Bounds on the Log Partition Function. IEEE Trans. Inform. Theory, 51(7), 2313–2335.

334. Wainwright, M. J., Jaakkola, T. S., and Willsky, A. S. (2005b). MAP Estimation Via Agreement on Trees: Message-Passing and Linear Programming. IEEE Trans. Inform. Theory, 51(11), 3697–3717.

335. Wainwright, M. J. and Maneva, E. (2005, September). Lossy source encoding via message-passing and decimation over generalized codewords of LDGM codes. In IEEE Int. Symp. on Inf. Theory, Adelaide, pp. 1493–1497.

336. Walkup, D.W. (1979). On the expected value of a random assignement problem. SIAM J. Comput., 8, 440–442.

337. Wang, C. C., Kulkarni, S. R., and Poor, H. V. (2006). Exhausting error-prone patterns in ldpc codes. IEEE Trans. Inform. Theory. Submitted.

338. Wästlund, J. (2008). An easy proof of the $\zeta(2)$ limit in the random assignment problem. Elect. Commmun. Prob., 13, 258–265.

339. Wong, K. Y. M. and Sherrington, D. (1988). Intensively connected spin glasses: towards a replica symmetry breaking solution of the ground state. J. Phys. A, 21, L459–L466.

340. Wormald, N. C. (1999). Models of random regular graphs. In Surveys in Combinatorics, 1999 (ed. J. D. Lamb and D. A. Preece), London Mathematical Society Lecture Note Series, pp. 239–298. Cambridge University Press.

341. Yakir, B. (1996). The Differencing Algorithm LDM for Partitioning: A Proof of a Conjecture of Karmarkar and Karp. Math. Oper. Res., 21, 85.

342. Yedidia, J. S., Freeman, W. T., and Weiss, Y. (2001). Generalized belief propagation. In Advances in Neural Information Processing Systems, NIPS, pp. 689–695. MIT Press.

343. Yedidia, J. S., Freeman, W. T., and Weiss, Y. (2005). Constructing Free Energy Approximations and Generalized Belief Propagation Algorithms. IEEE Trans. Inform. Theory, 51, 2282–2313.

344. Yuille, A. L. (2002). CCCP Algorithms to Minimize the Bethe and Kikuchi Free Energies: Convergent Alternatives to Belief Propagation. Neural Computation, 14, 691–1722.