大宽度与无限宽度深度学习：Les Houches 讲义

Les Houches Lectures on Deep Learning at Large & Infinite Width

Yasaman Bahri, Boris Hanin, Antonin Brossollet, Vittorio Erba, Christian Keup, Rosalba Pacelli, James B. Simon

审校稿：全文对读已完成，待最终验收

arXiv:2309.01592v3 · 2024
Model: 初译记录待核实；本轮审校 gpt-6.1-sol (high)
审核：曹溪能
Updated: 2026-11-04

摘要

这些讲义讲授于 2022 年 Les Houches 统计物理与机器学习暑期学校，重点讨论深度神经网络的无限宽度极限和大宽度区域。所涵盖的主题包括这类网络的各种统计与动力学性质。讲者尤其讨论了随机深度神经网络的性质；在无限宽度极限下，训练后的深度神经网络、线性模型、核与高斯过程之间出现的联系；以及对大但有限宽度网络在初始化时和训练后的微扰与非微扰处理。[1]

作者与单位

1. Yasaman Bahri：Google DeepMind，Mountain View，加利福尼亚州。

2. Boris Hanin：普林斯顿大学运筹学与金融工程系。

3. Antonin Brossollet：巴黎高等师范学院物理实验室，法国巴黎。

4. Vittorio Erba：洛桑联邦理工学院，SPOC 与 IdePHIcs 实验室。

5. Christian Keup：洛桑联邦理工学院，SPOC 实验室。

6. Rosalba Pacelli：都灵理工大学应用科学与技术系；博科尼大学人工智能实验室，米兰。

7. James B. Simon：加州大学伯克利分校物理系。

[1]本讲义根据 Yasaman Bahri 和 Boris Hanin 的报告整理，第一版由 Antonin Brossollet、Vittorio Erba、Christian Keup、Rosalba Pacelli 和 James Simon 编写。报告录像见 `https://www.youtube.com/playlist?list=PLEIq5bchE3R1QYiNthdj9rJDa4TUzR-Yb`。

目录

1 第一讲：Yasaman Bahri **4**
1.1 引言 . . . 4
1.2 问题设定 . . . 4
1.3 函数空间中的先验 . . . 4
1.4 深层全连接架构在函数空间中的先验 . . . 6
1.5 更复杂架构在函数空间中的先验 . . . 6
1.6 高斯过程的贝叶斯推断 . . . 8
1.7 神经网络高斯过程核递推在大深度下的固定点 . . . 9

2 第二讲 **12**
2.1 引言 . . . 12
2.2 Wick 定理 . . . 12
2.2.1 两点关联函数 . . . 12
2.2.2 四点关联函数 . . . 13
2.2.3 大 n 展开 . . . 14
2.3 无限宽极限下优化的梯度下降动力学 . . . 14
2.3.1 设定 . . . 14
2.3.2 神经网络函数的梯度下降动力学 . . . 15
2.3.3 关于归一化的说明 . . . 16
2.3.4 示例：单隐藏层神经网络 . . . 16
2.3.5 无限宽极限下的神经切线核 . . . 17
2.3.6 动力学的闭式解与等价线性模型 . . . 19
2.3.7 补充：两种参数化下的线性模型等价性 . . . 20

3 第三讲 **22**
3.1 引言 . . . 22
3.2 大但有限宽度下动力学的微扰理论 . . . 22
3.2.1 耦合常微分方程层级 . . . 22
3.2.2 含有限宽度主导阶 $1/n$ 修正的动力学 . . . 23
3.3 大宽度下的大学习率动力学：“弹射”机制 . . . 25

4 第四讲：Boris Hanin **28**
4.1 记号对照表 . . . 28
4.2 记号 . . . 28
4.3 主要问题：陈述、答案和动机 . . . 28
4.3.1 主要问题的精确陈述 . . . 28
4.4 主要问题的答案 . . . 29
4.5 动机 . . . 29
4.6 L/n 出现的直观理解 . . . 31

4.7 Yasaman 第一至第三讲的总结 . . . 32
4.8 神经元间相关性与非高斯涨落的形式化 . . . 33
4.9 定理 4.2 的证明 . . . 34
4.9.1 一些背景 . . . 34
4.9.2 第一步：归结为集体可观测量 . . . 35
4.10 第二步：将自平均可观测量 $\Sigma_{\alpha}^{(\ell)}$ 分解为均值与涨落 . . . 36
4.11 第三步：按中心化集体可观测量的幂展开 . . . 37
4.12 第四步：将 $k_{4;\alpha}^{(\ell+1)}$ 与修饰的两点函数联系起来并得到其递推 . . . 37
4.13 第五步：求解四点函数递推 . . . 38

5 第五讲 **39**
5.1 引言 . . . 39
5.2 目标 . . . 39
5.3 定理 5.1 证明的形式体系 . . . 40
5.4 使用路径表示的梯度公式 . . . 41
5.5 推导输入—输出 Jacobian 的 L/n 行为 . . . 41
5.5.1 二阶矩计算 . . . 42
5.5.2 四阶矩计算 . . . 42
5.5.3 对 NTK 的类似计算 . . . 44
5.6 开放问题与设想 . . . 44

译注：原文中的记号与推导疑点 **45**

参考文献 **48**

1 第一讲：Yasaman Bahri

1.1 引言

本系列讲义将聚焦深度神经网络的无限宽度极限与大宽度区域。系列讲义涵盖的部分主题包括：

- 恰好可解的模型；
- 平均场理论与高斯场论；
- 微扰理论与非微扰现象；
- 动力系统。

第一至第三讲由 Yasaman Bahri 主讲，第四和第五讲由 Boris Hanin 主讲。

1.2 问题设定

我们关心神经网络 $f_\theta : \mathbb{R}^{n_0} \to \mathbb{R}^{n_{L+1}}$，其中 n_0, n_{L+1} 分别是输入与输出维数，θ 表示神经网络参数的集合（例如，全连接网络的权重和偏置）。隐藏层宽度为 n_l、深度为 L 的一个“标准”全连接（FC）深度神经网络（NN）由以下迭代关系定义：

$$z_i^l(x) = b_i^l + \sum_{j=1}^{n_l} W_{ij}^l \phi\big(z_j^{l-1}(x)\big), \qquad 1 \le l \le L, \quad 1 \le i \le n_{l+1}, \tag{1}$$

$$z_i^0(x) = b_i^0 + \sum_{j=1}^{n_0} W_{ij}^0 x_j, \qquad f_i(x) := z_i^L(x). \tag{2}$$

其中 x 是输入，$z^l \in \mathbb{R}^{n_{l+1}}$ 是第 l 层的预激活向量，$\{b_i^l, W_{ij}^l\}_{ij}$ 是第 l 层的偏置与权重，ϕ 是诸如 tanh 或 ReLU 的非线性函数，后者定义为 $\phi(x) = \max(0, x)$。参数相互独立地初始化为

$$b_i^l \sim \mathcal{N}(0, \sigma_b^2), \qquad W_{ij}^l \sim \mathcal{N}\left(0, \frac{\sigma_w^2}{n_l}\right), \tag{3}$$

其中 $\mathcal{N}(\mu, \sigma^2)$ 是均值为 μ、方差为 σ^2 的正态分布。注意权重方差依赖于层宽的倒数，这将在后续讨论中发挥重要作用。我们将初始化时的参数分布称为先验。本讲义主要考虑标量输出 $n_{L+1} = 1$（结果可以直接推广到多维情形）以及均匀的隐藏层宽度 $n_i := n$，$1 \le i \le L$。

1.3 函数空间中的先验

在可能的情况下，将结果从神经网络参数空间转写到函数空间是有益的，尤其是对于表示可能存在高度冗余的神经网络。例如，全连接神经网络具有与某隐藏层相关联的置换对称性：

$$W_{ij}^{l+1}, W_{jk}^l \longrightarrow W_{i\pi(j)}^{l+1}, W_{\pi(j)k}^l, \qquad \text{对 } n \text{ 个元素的任意置换 } \pi, \tag{4}$$

因此两组不同的参数可能对应完全相同的函数。第一个自然问题是：参数先验诱导出怎样的函数先验？

定义 1 (高斯过程)**.** 若对任意有限输入集合 $\{x_1,\dots,x_m\}$，输出向量 $\{f(x_1),\dots,f(x_m)\}$ 是多元正态随机变量，其均值 $\mu_i=\mu(x_i)$、协方差 $K_{ij}=K(x_i,x_j)$，则函数 $f:\mathbb{R}^{n_0}\to\mathbb{R}$ 是从均值函数 $\mu:\mathbb{R}^{n_0}\to\mathbb{R}$、核函数 $K:\mathbb{R}^{n_0}\times\mathbb{R}^{n_0}\to\mathbb{R}$ 的高斯过程（GP）中抽取的一个样本。

结果 1 (见文献 [1])**.** 考虑一个只有一个隐藏层（按我们的记号 $L=1$）、宽度为 n 的全连接神经网络，其参数独立同分布地抽取为

$$b_i^0\sim\mathcal{N}(0,\sigma_b^2),\qquad W_{ij}^0\sim\mathcal{N}\left(0,\frac{\sigma_w^2}{n_0}\right),\qquad b_i^1\sim\mathcal{N}(0,\sigma_b^2),\qquad W_{ij}^1\sim\mathcal{N}\left(0,\frac{\sigma_w^2}{n}\right).\tag{5}$$

则在 $n\to\infty$ 极限下，对任意 $i=1,\dots,n_2$，输出 z_i^1 的分布是均值函数确定为 $\mu^1(x)=0$、核函数为 K^1 的高斯过程，其中

$$K^1(x,x')=\sigma_b^2+\sigma_w^2\mathbb{E}_{u_1,u_2\sim\mathcal{N}(0,\Sigma)}[\phi(u_1)\phi(u_2)],\tag{6}$$

$$\Sigma=\begin{bmatrix}K^0(x,x) & K^0(x,x')\\ K^0(x',x) & K^0(x',x')\end{bmatrix},\tag{7}$$

$K^0(x,x')=\sigma_b^2+\sigma_w^2(x\cdot x'/n_0)$，并且当 $i\neq j$ 时，不同输出 z_i^1,z_j^1 相互独立。

证明（非正式）. 考虑预激活的集合 $S:=\{z_i^1(x_a)\}_{a=1\dots m}^{i=1\dots n_2}$，它们是在给定输入值 $x_1,\dots,x_m$ 条件下的随机变量。回顾

$$z_i^1(x_a)=b_i^1+\sum_{j=1}^{n}W_{ij}^1\phi\big(z_j^0(x_a)\big).\tag{8}$$

注意每个 $z_i^1(x_a)$ 都是独立同分布随机变量之和（每项是两个随机变量之积）。在大 n 极限下对集合 S 应用中心极限定理（CLT），并注意方差和协方差都是有限的，可知 S 服从多元正态分布。由于当 $i\neq j$ 时，不同输出 z_i^1,z_j^1 的协方差另外还是零，它们相互独立。下文我们将不再显式提及 $a=1,\dots,m$ 的 x_a，而改用任意的 x,x'。请记住，随机性完全来自参数而非输入。

对任意 x,x'，高斯过程的协方差函数为

$$\begin{aligned}\mathbb{E}[z_i^1(x)z_i^1(x')]&=\mathbb{E}[b_i^1b_i^1]+\sum_{j,j'=1}^{n}\mathbb{E}\big[W_{ij}^1W_{ij'}^1\phi(z_j^0(x))\phi(z_{j'}^0(x'))\big]\\&=\sigma_b^2+\sum_{j,j'=1}^{n}\mathbb{E}[W_{ij}^1W_{ij'}^1]\mathbb{E}[\phi(z_j^0(x))\phi(z_{j'}^0(x'))]\\&=\sigma_b^2+\frac{\sigma_w^2}{n}\sum_{j,j'=1}^{n}\delta_{jj'}\mathbb{E}[\phi(z_j^0(x))\phi(z_{j'}^0(x'))]\\&=\sigma_b^2+\frac{\sigma_w^2}{n}\sum_{j=1}^{n}\mathbb{E}[\phi(z_j^0(x))\phi(z_j^0(x'))]\\&=\sigma_b^2+\sigma_w^2\mathbb{E}[\phi(z_j^0(x))\phi(z_j^0(x'))]\\&=:K^1(x,x').\end{aligned}\tag{9}$$

倒数第二行对任意 j 成立，其中用到了来自不同 $j=1,\dots,n$ 的贡献相同这一事实。类似地可以计算前一层预激活的协方差，得到

$$\mathbb{E}[z_i^0(x)z_i^0(x')]=\sigma_b^2+\sigma_w^2\left(\frac{x\cdot x'}{n_0}\right)=:K^0(x,x').\tag{10}$$

注意 z^0 的预激活也由多元正态分布描述，但这时是因为权重与偏置服从正态分布：求和包含 n_0 项，而与隐藏层大小 n 不同，我们保持 n_0 有限。最后注意，式 (9) 中剩下的期望可表示成核 $K^0(x,x')$ 的函数。事实上，由于 z^0 的高斯性，我们有

$$K^1(x,x') = \sigma_b^2 + \sigma_w^2 \mathbb{E}_{u_1,u_2\sim\mathcal{N}(0,\Sigma)}[\phi(u_1)\phi(u_2)], \tag{11}$$

$$\Sigma = \begin{bmatrix} K^0(x,x) & K^0(x,x') \\ K^0(x',x) & K^0(x',x') \end{bmatrix}. \tag{12}$$

□

1.4 深层全连接架构在函数空间中的先验

我们可以将上一结果推广到有限深度的全连接神经网络。取无限宽度极限至少有两种合理方式 [2, 3]：

- 依次取极限：从第一层到最后一层，逐层令每层宽度趋于无穷；
- 同时取极限：同时令每一层的宽度趋于无穷。

在这两种情形下，将先验 (5) 自然推广到多层，每个隐藏层的预激活及神经网络输出仍然是均值为零的高斯过程，其协方差函数 K^l 可迭代计算为

$$K^l(x,x') = \sigma_b^2 + \sigma_w^2 \mathbb{E}_{u_1,u_2\sim\mathcal{N}(0,\Sigma)}[\phi(u_1)\phi(u_2)], \tag{13}$$

$$\Sigma = \begin{bmatrix} K^{l-1}(x,x) & K^{l-1}(x,x') \\ K^{l-1}(x',x) & K^{l-1}(x',x') \end{bmatrix}, \tag{14}$$

初始协方差为 $K^0(x,x') = \sigma_b^2 + \sigma_w^2\big(x\cdot x'/n_0\big)$。两种情形的证明请参阅相关文献。

注意，$\mathbb{E}_{u_1,u_2\sim\mathcal{N}(0,\Sigma)}[\phi(u_1)\phi(u_2)]$ 是协方差矩阵 $\Sigma\in\mathbb{R}^{2\times2}$ 元素的函数。我们将其一般地写为

$$\mathcal{F}_\phi(\Sigma_{11},\Sigma_{12},\Sigma_{22}) := \mathbb{E}_{u_1,u_2\sim\mathcal{N}(0,\Sigma)}[\phi(u_1)\phi(u_2)]. \tag{15}$$

对于某些非线性函数 ϕ，这一函数事实上可以用闭式计算。对于 ReLU，即 $\phi(x)=\max(x,0)$，有 [4]

$$\mathcal{F}_{\mathrm{ReLU}}(\Sigma_{11},\Sigma_{12},\Sigma_{22}) = \frac{1}{2\pi}\sqrt{\Sigma_{11}\Sigma_{22}}\,[\sin\theta + (\pi-\theta)\cos\theta], \tag{16}$$

其中 $\theta = \arccos\big(\Sigma_{12}/\sqrt{\Sigma_{11}\Sigma_{22}}\big)$。

1.5 更复杂架构在函数空间中的先验

宽深度神经网络的先验收敛到高斯过程这一结果也适用于其他架构，如具有卷积层 [5] 或注意力层 [6] 的神经网络，只要其权重被独立同分布地初始化，且权重方差随隐藏层宽度按适当的倒数比例缩放。递推关系的形式取决于层的性质。

例如，通过堆叠一维卷积层构建的简单神经网络可由下式迭代定义：

$$z^l_{i,\alpha} = b^l_i + \sum_{j=1}^{n}\sum_{\beta=-k}^{k} W^l_{ij,\beta}\,\phi\big(z^{l-1}_{j,\alpha+\beta}(x)\big), \tag{17}$$

其中拉丁字母索引从 1 到 n 的通道；z 上的希腊字母索引从 1 到 D 的空间维度，D 是输入的空间维度；索引 β 遍历卷积滤波器的空间大小 $2k+1$。初始化时，我们将参数独立同分布地抽取为[2]

$$b_i^l \sim \mathcal{N}(0, \sigma_b^2), \qquad W_{ij,\beta}^l \sim \mathcal{N}\left(0, v_\beta \frac{\sigma_w^2}{n}\right), \tag{18}$$

其中 v_β 为不同空间坐标提供可能不均匀的幅度（均匀情形下 $v_\beta = 1/(2k+1)$） [7, 5]。我们令隐藏层通道数 $n \to \infty$，同时保持所有其他维度 k, D, n_0 固定。与前面一样，每个预激活与网络输出都是零均值高斯过程，而协方差函数依赖于层，还具有空间分量。事实上，

$$\begin{aligned} K_{\alpha,\alpha'}^l(x,x') = \mathbb{E}[z_\alpha^l(x) z_{\alpha'}^l(x')] &= \sigma_b^2 + \sum_{j,j'=1}^{n} \sum_{\beta,\beta'=-k}^{k} \mathbb{E}[W_{ij,\beta}^l W_{ij',\beta'}^l] \\ &\quad \times \mathbb{E}[\phi(z_{j,\alpha+\beta}^{l-1}(x))\phi(z_{j',\alpha'+\beta'}^{l-1}(x'))] \\ &= \sigma_b^2 + \sigma_w^2 \sum_{\beta=-k}^{k} v_\beta \mathbb{E}[\phi(z_{j,\alpha+\beta}^{l-1}(x))\phi(z_{j,\alpha'+\beta}^{l-1}(x'))] \\ &= \sigma_b^2 + \sigma_w^2 \sum_{\beta=-k}^{k} v_\beta \, \mathcal{F}_\phi\big(K_{\alpha+\beta,\alpha+\beta}^{l-1}(x,x), \\ &\qquad K_{\alpha+\beta,\alpha'+\beta}^{l-1}(x,x'), K_{\alpha'+\beta,\alpha'+\beta}^{l-1}(x',x')\big), \end{aligned} \tag{19}$$

其中 $\mathcal{F}_\phi$ 仍按式 (15) 定义，初始情形为

$$K_{\alpha,\alpha'}^0(x,x') = \sigma_b^2 + \sigma_w^2 \sum_{\beta=-k}^{k} v_\beta \frac{1}{n_0} \sum_{j=1}^{n_0} x_{j,\alpha+\beta} x'_{j,\alpha'+\beta}. \tag{20}$$

输出之前，通道索引与空间索引常被聚合成单个索引。下面介绍两种示例策略；此处 $\overline{W}, \overline{b}, \overline{z}$ 指输出层变量。

- **通过向量化聚合**。此例中，我们在通道和空间维度上共同展平最后一层隐藏层的预激活：

$$\overline{z}_i^{L+1}(x) = \overline{b}_i^{L+1} + \sum_{j=1}^{nD} \overline{W}_{ij}^{L+1} \phi(\mathrm{Vec}[z^L(x)]_j), \tag{21}$$

其中 n, D 分别为输入的通道与空间维数，$\mathrm{Vec}(\cdot)$ 是向量化算符。我们如前初始化 $\overline{b}$，并令 $\overline{W}_{ij} \sim \mathcal{N}(0, \sigma_w^2/(nD))$。网络输出的协方差为

$$\begin{aligned} \mathbb{E}[\overline{z}_i^{L+1}(x)\overline{z}_i^{L+1}(x')] &= \sigma_b^2 + \sum_{j,j'=1}^{nD} \mathbb{E}[\overline{W}_{ij}^{L+1}\overline{W}_{ij'}^{L+1}] \\ &\quad \times \mathbb{E}[\phi(\mathrm{Vec}[z^L(x)]_j)\phi(\mathrm{Vec}[z^L(x')]_{j'})] \\ &= \sigma_b^2 + \frac{\sigma_w^2}{D} \sum_{\alpha=1}^{D} \mathcal{F}_\phi\big(K_{\alpha,\alpha}^L(x,x), K_{\alpha,\alpha}^L(x,x'), K_{\alpha,\alpha}^L(x',x')\big). \end{aligned} \tag{22}$$

在此情形下，最终协方差依赖于两个输入在相同空间位置上的前一层协方差，忽略了完整张量 $K_{\alpha,\alpha'}^L(x,x')$ 所含的部分信息。

[2]同前，由于输入维度为 n_0，第一层参数的分布需作适当修改。

- **对空间索引聚合**。此例中，我们使用固定权重向量 h_α 对空间索引聚合：

$$\overline{z}_i^{L+1}(x) = \overline{b}_i^{L+1} + \sum_{j=1}^{n} \overline{W}_{ij}^{L+1} \sum_{\alpha=1}^{D} h_\alpha \phi(z_{j,\alpha}^{L}(x)), \tag{23}$$

  类似于前面的计算（取 $\overline{W}_{ij} \sim \mathcal{N}(0, \sigma_w^2/n)$），

$$\mathbb{E}[\overline{z}_i^{L+1}(x)\overline{z}_i^{L+1}(x')] = \sigma_b^2 + \sigma_w^2 \sum_{\alpha,\alpha'=1}^{D} h_\alpha h_{\alpha'} \mathcal{F}_\phi\big(K_{\alpha,\alpha}^{L}(x,x), K_{\alpha,\alpha'}^{L}(x,x'), K_{\alpha',\alpha'}^{L}(x',x')\big). \tag{24}$$

  注意，此时即使空间聚合是均匀的，即 $h_\alpha = 1/D$，最终协方差仍会收到前一层协方差的空间非对角贡献。

最后，我们指出残差神经网络是另一种容易处理的架构。预激活的形式为

$$z_i^l(x) = b_i^l + \sum_{j=1}^{n} W_{ij}^l \phi(z_j^{l-1}(x)) + \gamma^l z_i^{l-1}(x), \tag{25}$$

其中 γ^l 是固定超参数。此时核递推关系的形式为

$$K^l(x,x') = \sigma_b^2 + \sigma_w^2 \mathcal{F}_\phi\big(K^{l-1}(x,x), K^{l-1}(x,x'), K^{l-1}(x',x')\big) + (\gamma^l)^2 K^{l-1}(x,x'). \tag{26}$$

总之，我们已经看到，如何通过对不同架构类别的深度神经网络取自然的无限宽度极限而得到复合核与高斯过程。我们推导的量：

- 可以直接用于核岭回归或贝叶斯推断。在某些情形下，这些基于核的预测器可以与对应的神经网络模型一样好，甚至更好；
- 有助于进一步从理论上理解初始化时及训练后的深度神经网络。例如，理解实际数据上的这些复合核的结构，可以帮助我们洞察不同架构的优势。

1.6 高斯过程的贝叶斯推断

考虑数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1\ldots m}$。假设我们希望使用具有可学习参数 θ 的模型 $f_\theta(x)$，以贝叶斯方式在点 x_* 作出预测。令 $\vec{x} = [x_1, \ldots, x_m]^T$、$\vec{y} = [y_1, \ldots, y_m]^T$。在给定数据集 $\mathcal{D}$ 与 x_* 的条件下，输出 $z_* = f_\theta(x_*)$ 的分布为

$$p(z_* \mid \mathcal{D}, x_*) = \int d\theta \, p(z_* \mid \theta, x_*) \, p(\theta \mid \mathcal{D}). \tag{27}$$

为方便改写，我们引入训练数据上的函数值向量 $\vec{z} = [f_\theta(x_1), \ldots, f_\theta(x_m)]$。于是

$$p(z_* \mid \mathcal{D}, x_*) = \int d\vec{z} \, p(z_* \mid \vec{z}, \vec{x}, x_*) \, p(\vec{z} \mid \mathcal{D}), \tag{28}$$

其中我们把参数上的积分改为有限组函数值上的积分。

一个自然的问题是，什么条件下允许从参数空间转换到函数空间。一般来说，人们可能预期需要对模型能够表示的函数作泛函积分，即 $\int \mathfrak{D}z$。在这里，我们隐含地假设似然仅通过模型输

出来依赖参数。注意，在函数空间工作或许能更自然地约束模型的某些性质，如函数的光滑性；另一方面，其他形式的正则化（如参数的 L_2 正则化）可能更难以简单形式写出。

现在考虑一种具体的似然。根据贝叶斯定理，

$$p(\vec{z} \mid \mathcal{D}) \longrightarrow p(\vec{z} \mid \vec{y}) = \frac{p(\vec{y} \mid \vec{z})p(\vec{z})}{p(\vec{y})}, \tag{29}$$

（对于默认给定的输入，我们不再写出条件），并假设目标值与模型通过均值为零、方差为 σ_ϵ^2 的高斯噪声联系，则

$$p(\vec{y} \mid \vec{z}) \propto \prod_{i=1}^{m} \exp\left[-\frac{(y_i - z_i)^2}{2\sigma_\epsilon^2}\right]. \tag{30}$$

$p(z_* \mid \vec{z})$ 与 $p(\vec{z})$ 两项合起来给出先验分布 $p(z_*, \vec{z})$。对于高斯过程，这是一个均值与协方差依赖于输入 $(x_*, \vec{x})$ 的多元高斯分布。假设均值为零，则

$$p(z_*, \vec{z}) \propto \exp\left\{-\frac{1}{2}\begin{bmatrix} z_* & \vec{z} \end{bmatrix}\begin{bmatrix} K(x_*, x_*) & K(\vec{x}, x_*)^T \\ K(\vec{x}, x_*) & K(\vec{x}, \vec{x}) \end{bmatrix}^{-1}\begin{bmatrix} z_* \\ \vec{z} \end{bmatrix}\right\}, \tag{31}$$

其中 $K(\vec{x}, x_*)_i = K(x_i, x_*)$ 是 m 维列向量，$K(\vec{x}, \vec{x})_{ij} = K(x_i, x_j)$ 是 $m \times m$ 矩阵。

模型输出 z_* 在 x_* 处的预测分布 (28) 涉及以高斯函数为被积函数的积分，因此 $z_* \mid \mathcal{D}, x_* \sim \mathcal{N}(\mu_*, \sigma_*^2)$，其中

$$\begin{aligned} \mu_* &= K(\vec{x}, x_*)^T\big(K(\vec{x}, \vec{x}) + \sigma_\epsilon^2 I\big)^{-1}\vec{y}, \\ \sigma_*^2 &= K(x_*, x_*) - K(\vec{x}, x_*)^T\big(K(\vec{x}, \vec{x}) + \sigma_\epsilon^2 I\big)^{-1}K(\vec{x}, x_*). \end{aligned} \tag{32}$$

高斯过程的边缘似然 $p(\mathcal{D})$ 可解析写为

$$\log p(\mathcal{D}) = -\frac{1}{2}\vec{y}^T\big(K(\vec{x}, \vec{x}) + \sigma_\epsilon^2 I\big)^{-1}\vec{y} - \frac{1}{2}\log\det\big(K(\vec{x}, \vec{x}) + \sigma_\epsilon^2 I\big) - \frac{m}{2}\log 2\pi. \tag{33}$$

其中第一项描述对数据集的拟合，第二项代表偏好较简单协方差函数的复杂度惩罚。

与一般模型的贝叶斯推断不同——后者由于涉及积分而常需近似——高斯过程的贝叶斯推断 [8] 可以精确进行。借助前面讨论的无限宽神经网络与高斯过程之间的 “NNGP” 对应 [2]，我们可以利用所得的复合核，在这一极限下使用深度神经网络进行贝叶斯预测。

1.7 神经网络高斯过程核递推在大深度下的固定点

现在我们研究 NNGP 核递推在大深度 $l \to \infty$ 下的行为：

$$\begin{aligned} K^l(x, x') &= \sigma_b^2 + \sigma_w^2 \mathcal{F}_\phi\big(K^l(x, x), K^l(x, x'), K^l(x', x')\big), \\ K^0(x, x') &= \sigma_b^2 + \sigma_w^2\left(\frac{x \cdot x'}{n_0}\right). \end{aligned} \tag{34}$$

由于实践中训练深度神经网络是已知的难题，这些大深度极限已被用作代理指标 [9]，来识别可训练网络所在的超参数空间区域。（本例中，我们可能希望得到选择指导的超参数包括 σ_w, σ_b, L 和 ϕ。）一种假设认为，深度神经网络若要能通过反向传播训练，输入信息必须能够沿网络深度向前传播。作为信息论方法的替代，前向信号中所含信息量的一个代理是成对输入之间的协方

差。选择架构和初始化策略时应避开协方差函数迅速收敛到无结构极限的超参数空间区域。我们将简要介绍这一方向上针对全连接神经网络最简单的前向传播分析 [9]。随着深度学习理论进一步发展，人们已经建立类似但更全面的处理方法；可参见后续文献，例如 [7, 10, 11]。

考虑一对输入 x_α 与 x_β 之间的相关性。我们需要追踪 $K_{\alpha\alpha}, K_{\beta\beta}, K_{\alpha\beta}$ 三个量的递推关系。对角元素满足

$$K^l_{\alpha\alpha} = \sigma_b^2 + \sigma_w^2 \int Ds \left(\phi(\sqrt{K^{l-1}_{\alpha\alpha}}s)\right)^2, \tag{35}$$

其中 Ds 为标准高斯测度，而非对角元素满足

$$K^l_{\alpha\beta} = \sigma_b^2 + \sigma_w^2 \int Ds_1\, Ds_2\, \phi(u_1)\phi(u_2), \tag{36}$$

其中

$$\begin{aligned} u_1 &= \sqrt{K^{l-1}_{\alpha\alpha}}s_1, \\ u_2 &= \sqrt{K^{l-1}_{\beta\beta}}\left(c^{l-1}_{\alpha\beta}s_1 + \sqrt{1-(c^{l-1}_{\alpha\beta})^2}\,s_2\right), \\ c^l_{\alpha\beta} &= K^l_{\alpha\beta}/\sqrt{K^l_{\alpha\alpha}K^l_{\beta\beta}}. \end{aligned} \tag{37}$$

现在假设核的对角元素趋于固定点 q^*（对任意有界 ϕ 都会发生，且随深度收敛得很快；见文献 [9]）。此时注意到 $c^* = 1$ 始终是非对角协方差递推的固定点，因为此时恢复了对角元素固定点的条件。对于小偏离的主导阶，该固定点是稳定还是不稳定？将映射 $c^{l-1}_{\alpha\beta} \to c^l_{\alpha\beta}$ 在固定点附近展开，可知 $c^* = 1$ 的稳定性由下式控制：

$$\chi_1 = \frac{\partial c^l_{\alpha\beta}}{\partial c^{l-1}_{\alpha\beta}} = \sigma_w^2 \int Ds \left(\phi'(\sqrt{q^*}s)\right)^2. \tag{38}$$

若 $\chi_1 < 1$，则 $c^* = 1$ 是稳定固定点；若 $\chi_1 > 1$，则它不稳定。

通过在固定点附近将递推关系展开至主导阶，可得到随深度的收敛速率 [9]。对于对角元素，定义 $\epsilon^l := K^l_{\alpha\alpha} - q^*$，得到

$$\epsilon^l = \epsilon^{l-1}\left[\chi_1 + \sigma_w^2 \int Ds\, \phi''(\sqrt{q^*}s)\phi(\sqrt{q^*}s)\right] + O((\epsilon^{l-1})^2), \tag{39}$$

因此在大 l 时，$\epsilon^l = \epsilon^0 \exp(-l/\xi_q)$，其特征深度尺度为

$$\xi_q^{-1} = -\log\left[\chi_1 + \sigma_w^2 \int Ds\, \phi''(\sqrt{q^*}s)\phi(\sqrt{q^*}s)\right]. \tag{40}$$

为研究非对角元素，我们改为考察相关性 $\epsilon^l = c^l_{\alpha\beta} - c^*$。由于对角元素趋于其固定点 q^* 更快 [9]，我们代入 $K^l_{\alpha\alpha} = q^*$，得到

$$\epsilon^l = \epsilon^{l-1}\left[\sigma_w^2 \int Ds_1\, Ds_2\, \phi'(u_1^*)\phi'(u_2^*)\right] + O((\epsilon^{l-1})^2), \tag{41}$$

其中

$$\begin{aligned} u_1^* &= \sqrt{q^*}s_1, \\ u_2^* &= \sqrt{q^*}\left(c^*s_1 + \sqrt{1-(c^*)^2}\,s_2\right), \end{aligned} \tag{42}$$

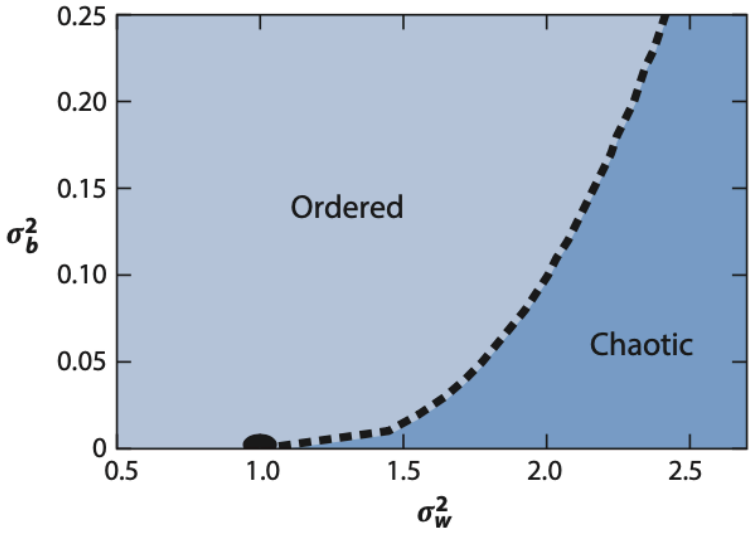


图 1: 对于非线性函数 $\phi = \tanh$，NNGP 递推关系的固定点在 (σ_b^2, σ_w^2) 平面上的相图，展示了由临界线分隔的有序相和混沌相。图转载自文献 [12]；另见文献 [9]。**译注：**图中 Ordered 表示有序相，Chaotic 表示混沌相。

特征深度由下式给出：

$$\xi_c = -\log\left[\sigma_w^2 \int Ds_1\, Ds_2\, \phi'(u_1^*)\phi'(u_2^*)\right]. \tag{43}$$

现在有三种情况：

- 若 $\chi_1 < 1$，则 $c^* = 1$ 是稳定固定点，我们将 (σ_b, σ_w) 平面上对应的区域称为有序相。在该相中，当两个输入 x_α, x_β 沿深度神经网络各层传播时，对随机网络取平均后，它们趋于以特征深度 ξ_c 指数快速对齐。

- 若 $\chi_1 > 1$，则 $c^* = 1$ 是不稳定固定点，(σ_b, σ_w) 平面上对应区域称为混沌相。此时另有一个稳定固定点 $c^* < 1$。两个输入 x_α, x_β 将随着网络深度，以特征深度尺度 ξ_c 指数快速趋于对所有 $\alpha \neq \beta$ 的均匀相关性（它可能为零）。

- 若 $\chi_1 = 1$，则 $c^* = 1$ 是边际稳定的，其稳定性由固定点附近展开的高阶项决定。(σ_b, σ_w) 平面上相应区域是一条临界线。在此相中，两个输入 x_α, x_β 之间的相关性以更慢的速率趋于固定点：是幂律而非指数速度。事实上可证明，当 $\chi_1 \to 1$ 时，$\xi_c \to +\infty$。人们发现，初始化超参数越靠近这条临界线，能够用反向传播训练的神经网络的最大深度就越大 [9]。

以 $\phi = \tanh$ 为例，图 1 的相图展示了由临界线分隔的有序相与混沌相。有序相与 $\sigma_b \gg \sigma_w$ 的区域平滑相连；直观而言，共享偏置支配作用于输入信号的权重，两个输入穿过随机网络更深的层后退化到共同的值（因此 $c^* = 1$ 固定点稳定）。混沌相与 $\sigma_b \ll \sigma_w$ 的区域平滑相连，在那里来自权重的随机性占主导，导致输入之间的相关性降低。

2 第二讲

2.1 引言

在上一讲中，我们讨论了 $n \to \infty$ 极限下深度神经网络在初始化时的性质，也讨论了该极限下由贝叶斯推断得到的预测。本讲转而关注用经验风险最小化训练深度神经网络，并理解同一隐藏层无限宽极限下，梯度下降或梯度流产生的优化动力学。

在此之前，我们先介绍一些工具，它们能够用于解析处理随机初始化深度神经网络偏离无限宽度极限的主导修正。这些工具也曾被用来为训练后的有限宽度深度神经网络构造微扰理论 [10]。

2.2 Wick 定理

Wick 定理是关于高斯随机变量的一个基本结果，它简化了涉及此类变量乘积期望的计算。

结果 2 (Wick 定理)**.** 设 $z \in \mathbb{R}^n$ 是中心化随机高斯向量，协方差矩阵为 K，即 $z \sim \mathcal{N}(0, K)$。那么 z 的元素任意乘积的期望可表示为对指标所有可能配对求和：

$$\begin{aligned}\mathbb{E}[z_{\mu_1} \cdots z_{\mu_{2m}}] &= \sum_{\text{所有配对}} \mathbb{E}[z_{\mu_{k_1}} z_{\mu_{k_2}}] \cdots \mathbb{E}[z_{\mu_{k_{2m-1}}} z_{\mu_{k_{2m}}}] \\ &= \sum_{\text{所有配对}} K_{\mu_{k_1}\mu_{k_2}} \cdots K_{\mu_{k_{2m-1}}\mu_{k_{2m}}}. \end{aligned} \tag{44}$$

（这里的结果针对包含偶数个元素的乘积，因为奇数个元素的乘积期望为零。）我们将用它计算随机初始化的深度线性网络中的高阶关联函数，以说明有限宽度的一些影响；这些影响不只出现在深度线性网络中，也延续到非线性网络中 [10]。

2.2.1 两点关联函数

利用 Wick 定理 (44)，我们计算随机初始化深度线性神经网络同一层任意两个预激活之间的协方差。为简单起见，假设没有偏置项 [10]：

$$\begin{aligned}\mathbb{E}[z^l_{i_1}(x_\alpha) z^l_{i_2}(x_\beta)] &= \sum_{j_1,j_2=1}^{n} \mathbb{E}[W^l_{i_1 j_1} W^l_{i_2 j_2} z^{l-1}_{j_1}(x_\alpha) z^{l-1}_{j_2}(x_\beta)] \\ &= \sum_{j_1,j_2=1}^{n} \mathbb{E}[W^l_{i_1 j_1} W^l_{i_2 j_2}] \mathbb{E}[z^{l-1}_{j_1}(x_\alpha) z^{l-1}_{j_2}(x_\beta)] \\ &= \delta_{i_1 i_2} \frac{\sigma_w^2}{n} \sum_{j_1,j_2=1}^{n} \delta_{j_1 j_2} \mathbb{E}[z^{l-1}_{j_1}(x_\alpha) z^{l-1}_{j_2}(x_\beta)] \\ &= \delta_{i_1 i_2} \frac{\sigma_w^2}{n} \sum_{j=1}^{n} \mathbb{E}[z^{l-1}_{j}(x_\alpha) z^{l-1}_{j}(x_\beta)]. \end{aligned} \tag{45}$$

将第 l 层关于输入 x_α, x_β 的两点关联函数分解为

$$\mathbb{E}[z^l_{i_1}(x_\alpha) z^l_{i_2}(x_\beta)] := \sigma_w^2 \delta_{i_1 i_2} G^l_{\alpha\beta}, \tag{46}$$

$$G^l_{\alpha\beta} = \frac{1}{n} \sum_{j=1}^{n} \mathbb{E}[z^l_j(x_\alpha) z^l_j(x_\beta)]. \tag{47}$$

有了这些定义，就可以把递推关系 (45) 简洁地写为

$$G^l_{\alpha\beta} = \sigma_w^2 G^{l-1}_{\alpha\beta}, \tag{48}$$

得到依赖深度的形式

$$G^l_{\alpha\beta} = (\sigma_w^2)^l G^0_{\alpha\beta}. \tag{49}$$

2.2.2 四点关联函数

类似地，我们得到四点关联函数的递推关系：

$$\begin{aligned}
\mathbb{E}[z^l_{i_1}\cdots z^l_{i_4}] &= \sum_{j_1\ldots j_4=1}^{n} \mathbb{E}[W^l_{i_1j_1}\cdots W^l_{i_4j_4}]\mathbb{E}[z^{l-1}_{j_1}\cdots z^{l-1}_{j_4}] \\
&= \frac{(\sigma_w^2)^2}{n^2}\sum_{j_1\ldots j_4=1}^{n}\big(\delta_{i_1i_2}\delta_{j_1j_2}\delta_{i_3i_4}\delta_{j_3j_4} + \delta_{i_1i_3}\delta_{j_1j_3}\delta_{i_2i_4}\delta_{j_2j_4} + \cdots\big) \\
&\quad \times \mathbb{E}[z^{l-1}_{j_1}z^{l-1}_{j_2}z^{l-1}_{j_3}z^{l-1}_{j_4}] \\
&= (\sigma_w^2)^2\big(\delta_{i_1i_2}\delta_{i_3i_4} + \delta_{i_1i_3}\delta_{i_2i_4} + \delta_{i_1i_4}\delta_{i_2i_3}\big) \\
&\quad \times \frac{1}{n^2}\sum_{j,k=1}^{n}\mathbb{E}[z^{l-1}_j z^{l-1}_j z^{l-1}_k z^{l-1}_k],
\end{aligned} \tag{50}$$

其中用 Wick 定理将期望值分解为指标配对之和。（为简单起见，我们考虑单一样本 $x_\alpha = x$ 并省略样本的记号，但该计算可以推广到任选四个样本的情形。）

我们再次将关联函数分解为刻画指标结构的一项与一个标量函数：

$$\mathbb{E}[z^l_{i_1}\cdots z^l_{i_4}] := \big(\delta_{i_1i_2}\delta_{i_3i_4} + \delta_{i_1i_3}\delta_{i_2i_4} + \delta_{i_1i_4}\delta_{i_2i_3}\big)G^l_4. \tag{51}$$

使用该分解，递推关系 (50) 的最后一个因子可写为

$$\begin{aligned}
\frac{1}{n^2}\sum_{j,k=1}^{n}\mathbb{E}[z^{l-1}_j z^{l-1}_j z^{l-1}_k z^{l-1}_k] &= \frac{1}{n^2}\sum_{j,k=1}^{n}(\delta_{jj}\delta_{kk} + \delta_{jk}\delta_{jk} + \delta_{jk}\delta_{jk})G^{l-1}_4 \\
&= \left(1 + \frac{2}{n}\right)G^{l-1}_4,
\end{aligned} \tag{52}$$

从而得到递推关系

$$G^l_4 = (\sigma_w^2)^2\left(1 + \frac{2}{n}\right)G^{l-1}_4. \tag{53}$$

由式 (50) 容易看出

$$G^0_4 = (G^0_2)^2, \tag{54}$$

其中 G^0_2 指两点关联函数：

$$G^0_2 = \frac{\sigma_w^2}{n_0}\sum_{j=1}^{n_0} x_j x_j. \tag{55}$$

展开递推关系得到

$$\begin{aligned} G_4^l &= (\sigma_w^2)^{2l}\left[\prod_{l'=1}^{l}\left(1+\frac{2}{n}\right)\right](G_2^0)^2 \\ &= \left[\prod_{l'=1}^{l}\left(1+\frac{2}{n}\right)\right](G_2^l)^2 \\ &= \left(1+\frac{2}{n}\right)^l (G_2^l)^2. \end{aligned} \tag{56}$$

2.2.3 大 n 展开

我们来讨论从 Wick 定理的这些简单应用中能学到什么 [10]。在 $n\to\infty$ 极限下，式 (56) 简化为 $G_4^l=(G_2^l)^2$，关联函数变为

$$\mathbb{E}[z_{i_1}^l z_{i_2}^l z_{i_3}^l z_{i_4}^l] = \big(\delta_{i_1i_2}\delta_{i_3i_4}+\delta_{i_1i_3}\delta_{i_2i_4}+\delta_{i_1i_4}\delta_{i_2i_3}\big)(G_2^l)^2, \tag{57}$$

这正是所有预激活均为高斯随机变量时所得的结果（事实上，我们从上一讲知道在这一极限下预激活由高斯过程描述）。大但有限的 n 会产生对高斯性的偏离，其主导阶形式为

$$\begin{aligned} G_4^l-(G_2^l)^2 &= \left[\left(1+\frac{2}{n}\right)^l-1\right](G_2^l)^2 \\ &= \frac{2l}{n}(G_2^l)^2+O\left(\frac{1}{n^2}\right), \end{aligned} \tag{58}$$

当深度不太大时有效。因此，四点关联函数相对于其无限宽形式的修正由网络深度与宽度之比 l/n 控制。事实上，这一比值也控制着经过训练的有限宽度深度神经网络中基于梯度的学习的修正 [10]。有限宽度时偏离高斯性的现象将在第四、五讲中进一步讨论。

2.3 无限宽极限下优化的梯度下降动力学

接下来，我们讨论在无限宽度极限下，通过梯度流（GF）或梯度下降（GD）在经验风险最小化框架内训练深度神经网络的动力学。我们专门考虑可以解析地推导出闭式解的平方损失。此设定进一步发展了无限宽神经网络、核回归和高斯过程之间丰富的联系 [13, 14]，其中一部分已在第一讲中建立。

2.3.1 设定

考虑深度为 L、宽度为 n 的全连接深度神经网络 $f_t(x):\mathbb{R}^{n_0}\to\mathbb{R}$。

其参数为 $\theta_t=\{W_{ij}^l(t),b_i^l(t)\}_{lij}$。我们认为神经网络函数和参数的时间依赖来自优化过程，并用 $f_t(x)=f(x,\theta_t)$ 强调这一点。对数据集 $\mathcal{D}=\{(x_\alpha,y_\alpha)\}_{\alpha=1}^m$，损失函数为

$$\mathcal{L}(\theta)=\frac{1}{m}\sum_{\alpha=1}^{m}\ell(f(x_\alpha,\theta),y_\alpha), \tag{59}$$

其中取 ℓ 为平方损失。有时我们写作 $\mathcal{L}_t=\mathcal{L}(\theta_t)$。

2.3.2 神经网络函数的梯度下降动力学

我们来研究对网络参数施加梯度下降所产生的深度神经网络函数动力学。参数的更新为

$$\theta_{\mu,t+1} = \theta_{\mu,t} - \eta \frac{\partial \mathcal{L}_t}{\partial \theta_\mu}, \tag{60}$$

其中 μ 标记可训练参数集合，η 为学习率。（下文在指标 μ 能明确缩并导数结构时使用它，否则将其省略。）利用链式法则从参数空间动力学转写为函数空间动力学，在学习率小的极限下展开得

$$\begin{aligned} f_{t+1}(x) = f(x,\theta_{t+1}) &= f\left(x, \theta_t - \eta \frac{\partial \mathcal{L}_t}{\partial \theta}\right) \\ &= f_t(x) - \eta \sum_\mu \frac{\partial f_t(x)}{\partial \theta_\mu} \frac{\partial \mathcal{L}_t}{\partial \theta_\mu} + \frac{\eta^2}{2} \sum_{\mu,\nu} \frac{\partial^2 f_t(x)}{\partial \theta_\mu \partial \theta_\nu} \frac{\partial \mathcal{L}_t}{\partial \theta_\mu} \frac{\partial \mathcal{L}_t}{\partial \theta_\nu} + \cdots . \end{aligned} \tag{61}$$

为说明问题，我们研究这些动力学的连续时间极限；通过保留 η 的高阶项，也可以直接推广到离散时间设定。令 η 趋于零，梯度流下函数 $f_t(x)$ 的演化为

$$\frac{df_t(x)}{dt} = -\sum_\mu \frac{\partial f_t(x)}{\partial \theta_\mu} \frac{\partial \mathcal{L}_t}{\partial \theta_\mu}. \tag{62}$$

将神经网络函数与参数之间的关系（这一映射编码了网络结构）同网络函数与损失之间的关系分开是有益的。将梯度改写为

$$\frac{\partial \mathcal{L}_t}{\partial \theta_\mu} = \sum_{\alpha \in \mathcal{D}} \frac{\partial \mathcal{L}_t}{\partial f_t(x_\alpha)} \frac{\partial f_t(x_\alpha)}{\partial \theta_\mu}, \tag{63}$$

于是函数演化可以写为

$$\begin{aligned} \frac{df_t(x)}{dt} &= -\sum_{\alpha \in \mathcal{D}} \frac{\partial \mathcal{L}_t}{\partial f(x_\alpha)} \left[\sum_\mu \frac{\partial f_t(x_\alpha)}{\partial \theta_\mu} \frac{\partial f_t(x)}{\partial \theta_\mu} \right] \\ &= -\sum_{\alpha \in \mathcal{D}} \frac{\partial \mathcal{L}_t}{\partial f(x_\alpha)} \Theta_t(x_\alpha, x). \end{aligned} \tag{64}$$

其中 $\Theta_t(x,x')$ 是如下定义的内积：

$$\Theta_t(x,x') := \sum_\mu \frac{\partial f_t(x)}{\partial \theta_\mu} \frac{\partial f_t(x')}{\partial \theta_\mu}. \tag{65}$$

文献 [13] 首次研究了这些动力学的 $n \to \infty$ 极限，并引入 $\Theta_t(x,x')$。随机初始化网络中 Θ 的无限宽极限称为*神经切线核*（NTK），它将在后续讨论中发挥关键作用。下文我们也用这个术语指代动力学变量 $\Theta_t(x,x')$，它可以在非初始化时刻或有限大小网络中求值。

对于所考虑的损失形式，$\partial \mathcal{L}_t / \partial f(x)$ 只依赖于 $f_t(x)$。然而，$\Theta_t(x,x')$ 一般是一个新变量，需要追踪其动力学才能得到封闭方程组。时间导数完全来自参数动力学，因此可将算符替换为

$$\frac{d}{dt} = \sum_\mu \frac{\partial \theta_\mu}{\partial t} \frac{\partial}{\partial \theta_\mu}. \tag{66}$$

NTK 的时间演化为

$$\begin{aligned}\frac{d\Theta_t(x,x')}{dt} &= \sum_{\mu}\left[\frac{d}{dt}\left(\frac{\partial f_t(x)}{\partial\theta_\mu}\right)\frac{\partial f_t(x')}{\partial\theta_\mu}+\frac{\partial f_t(x)}{\partial\theta_\mu}\frac{d}{dt}\left(\frac{\partial f_t(x')}{\partial\theta_\mu}\right)\right]\\ &= \sum_{\mu,\nu}\left[\frac{\partial\theta_\nu}{\partial t}\frac{\partial}{\partial\theta_\nu}\left(\frac{\partial f_t(x)}{\partial\theta_\mu}\right)\frac{\partial f_t(x')}{\partial\theta_\mu}+\frac{\partial f_t(x)}{\partial\theta_\mu}\frac{\partial\theta_\nu}{\partial t}\frac{\partial}{\partial\theta_\nu}\left(\frac{\partial f_t(x')}{\partial\theta_\mu}\right)\right]\\ &= -\sum_{\mu,\nu}\left[\frac{\partial\mathcal{L}_t}{\partial\theta_\nu}\frac{\partial}{\partial\theta_\nu}\left(\frac{\partial f_t(x)}{\partial\theta_\mu}\right)\frac{\partial f_t(x')}{\partial\theta_\mu}+\frac{\partial f_t(x)}{\partial\theta_\mu}\frac{\partial\mathcal{L}_t}{\partial\theta_\nu}\frac{\partial}{\partial\theta_\nu}\left(\frac{\partial f_t(x')}{\partial\theta_\mu}\right)\right] \qquad (67)\\ &= -\sum_{\alpha\in\mathcal{D}}\frac{\partial\mathcal{L}_t}{\partial f(x_\alpha)}\left[\sum_{\mu,\nu}\left(\frac{\partial^2 f_t(x)}{\partial\theta_\mu\partial\theta_\nu}\frac{\partial f_t(x_\alpha)}{\partial\theta_\nu}\frac{\partial f_t(x')}{\partial\theta_\mu}\right.\right.\\ &\qquad\left.\left.+\frac{\partial^2 f_t(x')}{\partial\theta_\mu\partial\theta_\nu}\frac{\partial f_t(x_\alpha)}{\partial\theta_\nu}\frac{\partial f_t(x)}{\partial\theta_\mu}\right)\right],\end{aligned}$$

其中从第二行到第三行使用了参数的梯度流。

因此，NTK 动力学由式 (67) 方括号中的量控制，它涉及网络映射 $\theta\mapsto f(x)$ 的一阶与二阶导数的缩并。一般而言，该量可能是不同于 f,Θ 的新动力学变量；描述函数空间动力学的完整方程组通常在这一层级并不封闭（即仅用式 (64) 和式 (67)），需要像处理 Θ 那样生成更多方程。我们将在下一讲回到这一过程。

2.3.3 关于归一化的说明

构建并训练神经网络时，需要选择参数的参数化方式以及优化前的初始化方式。迄今我们的介绍遵循了历史发展；为与后续文献保持一致，现在改用一种不同的参数化和初始化，在文献中称为 *NTK 参数化* [13, 14]。在层间变换中，我们将权重前依赖于大小的因子 $\sigma_w/\sqrt{n_l}$ 显式提出（重要的是大小依赖性，而非 $O(1)$ 的常数），转而使用初始化方案 $W^l_{ij}\sim\mathcal{N}(0,1)$。相比之下，迄今采用的方案将适当的宽度标度吸收到初始化中，例如 $W^l_{ij}\sim\mathcal{N}(0,\sigma_w^2/n_l)$；文献称之为*标准参数化*，它在深度学习实践中也很常见。两种方案在无限宽极限下得到相同的高斯过程，但一般网络在梯度下降下的动力学可能有所不同。参数化方式还会影响合适的超参数（例如梯度下降的学习率）如何依赖于网络大小。（在标准参数化中，学习率会隐式依赖于隐藏层大小。）此后我们使用 NTK 参数化，因为它使无限宽极限行为更显式；但我们讨论的重要特征，尤其是无限宽极限、核回归与高斯过程之间的联系，不会受到影响，因此这样做并不失一般性。关于 NTK 与标准参数化之间差异的进一步讨论，参见文献 [14]。顺便指出，自上述早期工作以来，关于参数化、超参数选择与无限宽极限已发展出丰富的文献。

2.3.4 示例：单隐藏层神经网络

我们来看一个具体例子：单隐藏层神经网络。为简单起见，将偏置设为零。隐藏层预激活和输出为

$$\begin{aligned}z_i^0(x) &= \sum_{k=1}^{n_0}\sigma_w\frac{W^0_{ik}}{\sqrt{n_0}}x_k,\\ f(x) &= \sum_{i=1}^{n}\sigma_w\frac{W^1_i}{\sqrt{n}}\phi(z_i^0(x)).\end{aligned} \qquad (68)$$

该网络的神经切线核为

$$\Theta(x,x') = \frac{\sigma_w^2}{n}\sum_{i=1}^{n}\phi(z_i^0(x))\phi(z_i^0(x')) + \left(\frac{\sigma_w^2}{n}\sum_{i=1}^{n}(W_i^1)^2\phi'(z_i^0(x))\phi'(z_i^0(x'))\right)\left(\frac{\sigma_w^2}{n_0}\sum_{j=1}^{n_0}x_j x_j'\right). \tag{69}$$

预激活的训练动力学满足

$$\frac{dz_i^0(x)}{dt} = -\sum_{\alpha\in\mathcal{D}}\frac{\partial\mathcal{L}_t}{\partial f(x_\alpha)}\frac{\sigma_w W_i^1\phi'(z_i^0(x_\alpha))}{\sqrt{n}}\left(\frac{\sigma_w^2}{n_0}\sum_{j=1}^{n_0}x_{\alpha,j}x_j\right), \tag{70}$$

最后一层权重的动力学为

$$\frac{dW_i^1}{dt} = -\sum_{\alpha\in\mathcal{D}}\frac{\partial\mathcal{L}_t}{\partial f(x_\alpha)}\frac{\sigma_w\phi(z_i^0(x_\alpha))}{\sqrt{n}}. \tag{71}$$

粗略估计表明，在初始化时这两个量都随着 $n\to\infty$ 而消失：事实上，$|dz_i^0/dt|_{t=0}\sim O(1/\sqrt{n})$ 且 $|dW_i^1/dt|_{t=0}\sim O(1/\sqrt{n})$。这些项对 Θ_t 的动力学有贡献；简单计算提示，在 $n\to\infty$ 时，对初始化时的 NTK 演化估计也得到类似的消失：

$$\left|\frac{d\Theta_t(x,x')}{dt}\right|\Big|_{t=0}\xrightarrow[n\to\infty]{}0. \tag{72}$$

另一方面，我们已在上面计算出 Θ_t，它在初始化时当 $n\to\infty$ 为 $O(1)$。因此，基于这些初始化估计所暗示的图景是：假设它们在训练期间仍成立，则在此极限下单个参数和隐藏层预激活在动力学下不演化，而 NTK 保持其初值。

2.3.5 无限宽极限下的神经切线核

我们将从物理学家的角度讨论无限宽极限下 NTK 在初始化时及训练后的行为。当网络参数本身从一个分布中抽取时，NTK 一般是随机变量。然而，由于大数定律，当 $n\to\infty$ 时某些性质变得确定。第一个主要结果指出，初始化时的 NTK 在 $n\to\infty$ 时趋于确定量，其递推关系类似于第一讲中为 NNGP 推导的递推关系。第二个主要结果考虑 $n\to\infty$ 时 NTK 的动力学：令人惊讶的是，NTK 在整个训练过程中保持不变。上一节对单隐藏层神经网络在初始化时所作的粗略估计已经暗示了这两个结果：我们发现 $\Theta_{t=0}\sim O(1)$ 且 $d\Theta_{t=0}/dt\to 0$。

NTK 的恒定性使我们能够解析求解网络演化，并给出深度神经网络学习与核回归之间的联系。

初始化。

结果 3 ([13])**.** 对于初始化时深度为 L、非线性函数为 ϕ 的网络，依次令各层宽度 $n\to\infty$，*NTK* Θ^L 收敛于确定性极限核：

$$\Theta^{L,kj}\to\Theta_0^L\cdot\delta_{kj}, \tag{73}$$

$$\Theta^{L,kj}(x,x') := \sum_{\mu}\frac{\partial f_k(x)}{\partial\theta_\mu}\frac{\partial f_j(x')}{\partial\theta_\mu}, \tag{74}$$

这里考虑一般的非标量映射 $f:\mathbb{R}^{n_0}\to\mathbb{R}^{n_{L+1}}$。

其中 $\Theta_0^L : \mathbb{R}^{n_0} \times \mathbb{R}^{n_0} \to \mathbb{R}$ 是一个核，我们将在下面推导其递推关系，同时触及这一结果证明中的主要思想；完整技术细节参见文献 [13]。可以通过对网络深度归纳理解结果如何产生。依次令每个隐藏层大小趋于无穷时，我们利用以下事实：来自该层的预激活分布由高斯过程描述，其协方差函数由第一讲所讨论的 NNGP 核给出。

为推导递推关系，我们将参数分成两组，分别对应最后一层及网络中更早的层：

$$\begin{aligned}\Theta^{L,kj}(x,x') &= \sum_{\mu} \frac{\partial f_k(x)}{\partial \theta_\mu}\frac{\partial f_j(x')}{\partial \theta_\mu} \\ &= \sum_{\substack{\mu \in \text{最后一层} \\ L}} \frac{\partial f_k(x)}{\partial \theta_\mu}\frac{\partial f_j(x')}{\partial \theta_\mu} + \sum_{\substack{\mu \in \text{更早各层} \\ 1,\ldots,L-1}} \frac{\partial f_k(x)}{\partial \theta_\mu}\frac{\partial f_j(x')}{\partial \theta_\mu}.\end{aligned} \tag{75}$$

层间变换采用 NTK 参数化，

$$f_k(x) = z_k^L(x) = \sigma_b b_k^L + \sum_{i=1}^{n} \sigma_w \frac{W_{ki}^L}{\sqrt{n}} \phi(z_i^{L-1}(x)), \tag{76}$$

NTK 的形式为

$$\begin{aligned}\Theta^{L,kj}(x,x') = \delta_{kj}\sigma_b^2 &+ \delta_{kj}\frac{\sigma_w^2}{n}\sum_{i=1}^{n}\phi(z_i^{L-1}(x))\phi(z_i^{L-1}(x')) \\ &+ \delta_{kj}\sigma_w^2 \sum_{i,s=1}^{n} \frac{W_{ki}^L W_{js}^L}{n}\phi'(z_i^{L-1}(x))\phi'(z_s^{L-1}(x')) \sum_{\substack{\mu \in \text{更早各层} \\ 1,\ldots,L-1}} \frac{\partial z_i^{L-1}(x)}{\partial \theta_\mu}\frac{\partial z_s^{L-1}(x')}{\partial \theta_\mu}.\end{aligned} \tag{77}$$

利用归纳假设可简化最后一项：

$$\begin{aligned}\Theta^{L,kj}(x,x') = \delta_{kj}\Bigg[\sigma_b^2 &+ \frac{\sigma_w^2}{n}\sum_{i=1}^{n}\phi(z_i^{L-1}(x))\phi(z_i^{L-1}(x')) \\ &+ \frac{\sigma_w^2}{n}\sum_{i=1}^{n}(W_{ki}^L)^2\phi'(z_i^{L-1}(x))\phi'(z_i^{L-1}(x'))\Theta^{L-1}(x,x')\Bigg].\end{aligned} \tag{78}$$

在无限宽极限下，第二项和第三项是独立同分布随机变量的平均。因此，由大数定律，当 $n \to \infty$ 时它们集中到各自的均值。由于 z^{L-1} 的分布由高斯过程给出，我们还可进一步简化表达式。回顾第 1.4 节关于深层全连接架构先验的讨论，令

$$\begin{aligned}\mathcal{F}_\phi(\Sigma) &= \mathbb{E}_{(u,v)\sim\mathcal{N}(0,\Sigma)}[\phi(u)\phi(v)], \\ \widetilde{\mathcal{F}}_\phi(\Sigma) &= \mathbb{E}_{(u,v)\sim\mathcal{N}(0,\Sigma)}[\phi'(u)\phi'(v)],\end{aligned} \tag{79}$$

其中

$$\Sigma = \begin{pmatrix} K_{11} & K_{12} \\ K_{21} & K_{22} \end{pmatrix}. \tag{80}$$

第一项和第二项集中到

$$\begin{aligned}\sigma_b^2 + \sigma_w^2\mathbb{E}[\phi(z_i^{L-1}(x))\phi(z_i^{L-1}(x'))] &= \sigma_b^2 + \sigma_w^2\mathcal{F}_\phi(K^{L-1}(x,x), K^{L-1}(x,x'), K^{L-1}(x',x')) \\ &= K^L(x,x').\end{aligned} \tag{81}$$

当 $n \to \infty$ 时第三项变为

$$\sigma_w^2 \mathbb{E}[(W_{ki}^L)^2]\mathbb{E}[\phi'(z_i^{L-1}(x))\phi'(z_i^{L-1}(x'))]\Theta^{L-1}(x,x') = \sigma_w^2 \widetilde{\mathcal{F}}_\phi(K^{L-1}(x,x),\ldots)\Theta^{L-1}(x,x'). \quad (82)$$

综合起来，在随机初始化的无限宽深度神经网络中，NTK 满足如下递推关系：

$$\Theta^{L,kj}(x,x') = \delta_{kj}\big[K^L(x,x') + \sigma_w^2 \widetilde{\mathcal{F}}_\phi(K^{L-1}(x,x), K^{L-1}(x,x'), K^{L-1}(x',x'))\Theta^{L-1}(x,x')\big]. \quad (83)$$

因此 NTK 同时依赖于前向传播信号的两点关联函数（即 K^L）及反向传播信号（如涉及 ϕ 的导数的积分，有时可以闭式计算）。

训练。 在第 2.3.4 节研究单隐藏层神经网络时，我们看到，依赖于大小的参数化（或初始化）因子 $1/\sqrt{n}$，使层中的单个权重矩阵元素或单个预激活等动力学变量，相对于优化时间的变化率在初始化时随着 $n \to \infty$ 变得无穷小。这源自依赖 n 的倒数因子与其他保持 $O(1)$ 的量的组合，进而导致初始化时 NTK 时间导数消失。事实上，对于某些损失函数（例如这里考虑的平方损失），这个时间导数的消失在训练期间仍然成立 [13]，因此在无限宽极限下，$\Theta_t(x,x')$ 等宏观变量以及单个参数和预激活都冻结在各自的初值。（虽然这些动力学变量在 $n \to \infty$ 的优化过程中保持初值，但它们共同仍能使神经网络函数适应并拟合训练数据。）非正式地总结为：

结果 4 ([13])**.** *在均方误差的梯度流下，当 $n \to \infty$ 时，NTK 在训练期间保持不变并等于初值：*

$$\Theta_t^{L,kj} \to \Theta_0^L \delta_{kj}. \quad (84)$$

因此，神经网络函数的微分方程具有简单形式

$$\frac{df_t(x)}{dt} = -\sum_{\alpha\in\mathcal{D}} \frac{\partial \mathcal{L}_t}{\partial f(x_\alpha)} \Theta_0(x_\alpha, x) = -\sum_{\alpha\in\mathcal{D}} \big(f_t(x_\alpha) - y_\alpha\big)\Theta_0(x_\alpha, x), \quad (85)$$

它可以精确求解。

2.3.6 动力学的闭式解与等价线性模型

我们可以从线性常微分方程 (85) 推导 $f_t(x)$ 的显式解。不过，在此之前，我们讨论动力学的一个等价表述，它有助于理解在此无限宽极限下学到的模型的复杂度，并给出参数空间中的描述。如下一节的结果 5 所述，无限宽极限下神经网络函数的优化动力学等价于函数实现关于网络参数的一阶 Taylor 展开 [14]；更精确地说，它实现了如下特定线性模型：

$$f_t^{\text{lin}}(x) := f_0(x) + \nabla_\theta f_0(x)|_{\theta=\theta_0} \cdot \omega_t, \quad (86)$$

其中 $\omega_t = \theta_t - \theta_0$ 是参数在训练期间相对初值的变化。注意这个模型对输入 x 仍然是非线性的。因此，我们也可以研究无限宽极限下的参数空间动力学，类似于式 (85)，得到关于网络参数 θ_t 的线性常微分方程。令 $\mathcal{X}$ 和 $\mathcal{Y}$ 表示在样本维度 $m = 1,\ldots,M$ 上向量化的训练输入和目标值集合。闭式求解常微分方程得到

$$\omega_t = -\nabla_\theta f_0(\mathcal{X})^\top \cdot \Theta_0^{-1} \cdot (I - e^{-\Theta_0 t}) \cdot (f_0(\mathcal{X}) - \mathcal{Y}), \quad (87)$$

$$f_t^{\text{lin}}(\mathcal{X}) = (I - e^{-\Theta_0 t})\mathcal{Y} + e^{-\Theta_0 t} f_0(\mathcal{X}), \quad (88)$$

其中 $\Theta_0 \equiv \Theta_0(\mathcal{X},\mathcal{X})$。无限宽极限下的神经网络函数值（等价地，线性模型 (86) 的值）为

$$\begin{aligned} f_t(x) = & \underbrace{\Theta_0(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot(I-e^{-\Theta_0 t})\cdot\mathcal{Y}}_{\mu_t(x)} \\ & + \underbrace{f_0(x)-\Theta_0(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot(I-e^{-\Theta_0 t})\cdot f_0(\mathcal{X})}_{\gamma_t(x)}, \end{aligned} \tag{89}$$

其中我们将所有依赖初始函数的项合并在 $\gamma_t(x)$ 中。虽然我们求解的是某个特定无限宽随机网络实例的动力学，但若考虑由 f_0 的初始分布（即 $f_0(x)$ 是高斯过程样本）诱导的 $f_t(x)$ 的分布，会发现 $f_t(x)$ 也由一个高斯过程描述，其均值和协方差函数可以从式 (89) 算出。（我们将各项分成 $\mu_t(x)$ 与 $\gamma_t(x)$，以提示它们分别对 $f_t(x)$ 的均值和方差有贡献。）这一高斯过程可以与无限宽极限下由贝叶斯推断所得的高斯过程 (32) 比较。由经验风险最小化与梯度流得到的高斯过程具有如下均值和方差 [14]：

$$\begin{aligned} \mu(x) &= \Theta_0(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot\mathcal{Y}, \\ \sigma^2(x) &= K(x,x)+\Theta_0(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot K\cdot\Theta_0^{-1}\cdot\Theta_0(\mathcal{X},x) \\ &\quad -\big(\Theta_0(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot K(\mathcal{X},x)+K(x,\mathcal{X})\cdot\Theta_0^{-1}\cdot\Theta_0(\mathcal{X},x)\big). \end{aligned} \tag{90}$$

（回顾一下，不带变量的 Θ_0, K 指在训练样本 $\mathcal{X}$ 上求值得到的 $m\times m$ 矩阵。）

出人意料的是，我们发现优化下的无限宽极限使深度神经网络动力学恰好可解。原则上，结果本可能十分复杂，且在具有无穷多个参数时，学到的函数可能相当不良；然而，动力学却有相对简单的描述：它由与深度神经网络相联系、可通过递推关系计算的核 Θ_0 刻画。我们再次强调，这种简单性来自深度学习中神经网络参数的常见表示方式，无论是通过显式还是隐式涉及隐藏层大小的因子。

2.3.7 补充：两种参数化下的线性模型等价性

在第 2.3.6 节，我们提到无限宽度下的梯度流动力学在训练过程中实现了神经网络函数与参数之间的线性关系 (86)，而这等价于当 $n\to\infty$ 时神经切线核 Θ 保持初值 Θ_0。虽然我们重点讨论的是梯度流，但无限宽深度神经网络动力学、线性模型、核回归与高斯过程之间的这些等价关系，在学习率不超过某个最大值时对梯度下降同样成立。下面我们非正式地陈述这些结果 [14]，强调最大学习率，并对比结果在 NTK 与标准参数化下的表现。

结果 5 ([14])**.** *假设初始化时 NTK 的最小特征值为正，即 $\lambda_{\min}>0$，令 $\lambda_{\max}$ 为最大特征值。在学习率 $\eta<\eta_{\text{critical}}=2/(\lambda_{\min}+\lambda_{\max})$ 的梯度下降下，采用 NTK 参数化，有*

$$\begin{aligned} \sup_{t\ge 0}\|f_t(x)-f_t^{\text{lin}}(x)\|_2 &= O\left(\frac{1}{\sqrt{n}}\right), \\ \sup_{t\ge 0}\frac{\|\theta_t-\theta_0\|_2}{\sqrt{n}} &= O\left(\frac{1}{\sqrt{n}}\right) \qquad \text{当} n\to\infty, \\ \sup_{t\ge 0}\|\Theta_t-\Theta_0\|_F &= O\left(\frac{1}{\sqrt{n}}\right). \end{aligned} \tag{91}$$

在标准参数化下(参见第 2.3.3 节),需要 $\eta_0 < \eta_{\text{critical}}$,而梯度下降使用的学习率为 $\eta := \eta_0/n$。在此参数化下，将神经切线核定义为

$$\Theta = \frac{1}{n}\sum_{\mu} \frac{\partial f(x)}{\partial \theta_\mu}\frac{\partial f(x')}{\partial \theta_\mu}, \tag{92}$$

相应的标度为

$$\begin{aligned} \sup_{t\geq 0} \|f_t(x) - f_t^{\text{lin}}(x)\|_2 &= O\left(\frac{1}{\sqrt{n}}\right), \\ \sup_{t\geq 0} \|\theta_t - \theta_0\|_2 &= O\left(\frac{1}{\sqrt{n}}\right) \qquad \text{当} n\to\infty, \\ \sup_{t\geq 0} \|\Theta_t - \Theta_0\|_F &= O\left(\frac{1}{\sqrt{n}}\right). \end{aligned} \tag{93}$$

可见，两种参数化在无限宽极限下的主要区别是优化过程中参数移动的 L_2 距离界以及最大学习率的形式。

3 第三讲

3.1 引言

本讲超越恰好可解的无限宽极限，讨论在大但有限宽度下可见的微扰和非微扰修正。第二讲讨论的恰好可解极限的一个特点是不存在 “特征学习”；相反，模型依靠初始化时的一组固定随机特征作预测。等价地，神经切线核在训练过程中不变。深度神经网络的有限大小隐藏层则会产生 “弱” 或 “强” 程度的特征学习，本讲的一个目标是说明这种特征学习的两种理论描述。

我们先回顾第 2.3.2 节提到的函数空间描述，它产生为实现闭合所需的一系列耦合微分方程。这一层级可以截断，用来计算有限宽度带来的主导阶修正 [15, 16]。[3]然后，我们给出一个对比例子：某个极简模型在大 n 下的学习行为与恰好可解的核极限及其微扰修正大不相同；这一现象称为 “弹射动力学” [17]。当梯度下降的学习率大于临界值（结果 5）时，就会出现该现象。

3.2 大但有限宽度下动力学的微扰理论

在第 2.3.2 节中，我们推导了梯度流下网络函数与动力学神经切线核的演化常微分方程。(此处我们用 $R_\alpha := \partial \mathcal{L}_t / \partial f(x_\alpha) = f_t(x_\alpha) - y_\alpha$ 简记由损失产生的残差。) 这些方程为

$$\frac{df_t(x)}{dt} = -\sum_{\alpha\in\mathcal{D}} \underbrace{\frac{\partial \mathcal{L}_t}{\partial f(x_\alpha)}}_{\equiv R_{\alpha,t}} \Theta_t(x_\alpha, x), \tag{94}$$

$$\frac{d\Theta_t(x,x')}{dt} = -\sum_{\alpha\in\mathcal{D}} R_{\alpha,t} \underbrace{\left[\sum_{u,v} \frac{\partial f_t(x_\alpha)}{\partial\theta_u} \frac{\partial^2 f_t(x)}{\partial\theta_u \partial\theta_v} \frac{\partial f_t(x')}{\partial\theta_v} + (x \leftrightarrow x')\right]}_{\mathbb{O}_3(x,x',x_\alpha)}. \tag{95}$$

这里用 $(x \leftrightarrow x')$ 表示方括号中前一项交换 x 与 x' 后得到的表达式（因此注意 $\mathbb{O}_3$ 在交换参数 x, x' 下对称)。

3.2.1 耦合常微分方程层级

虽然这些常微分方程和新动力学变量（如 $\mathbb{O}_3$）的具体形式依赖于具体神经网络，但耦合常微分方程组一般可能在这一阶不封闭。因此，我们通过计算出现的新变量的时间导数，继续生成该层级中的新方程。总体上，得到关于动力学变量 $\mathbb{O}_s(x_1, \ldots, x_s, t)$ 的耦合常微分方程层级，这些变量涉及网络函数关于参数的高阶及低阶导数在网络参数上的特定缩并。我们称其为函数空间描述，因为动力学变量的自变量都位于样本空间 $x \in \mathbb{R}^{n_0}$，而新变量的定义中对神经网络参数求和。[4]

继续上述过程，我们通过一个新变量 $\mathbb{O}_4$ 推导 $\mathbb{O}_3$ 的演化：

$$\frac{d\mathbb{O}_{3,t}(x,x',x_\alpha)}{dt} = -\sum_{\beta\in\mathcal{D}} R_{\beta,t} \mathbb{O}_{4,t}(x,x',x_\alpha,x_\beta), \tag{96}$$

[3]虽然这里不讨论深度效应，但文献 [10] 对其进行了处理。

[4]这些常微分方程最先在文献 [15] 中以物理学层面的严格性针对深度线性和 ReLU 网络引入并研究；这里遵循该文。其后文献 [16] 从数学严格的角度进行分析。文献 [10] 引入并研究了一组相关变量。

以此类推。为写出紧凑表达式，定义

$$\begin{aligned}\mathbb{O}_1(x_1) &:= f(x_1),\\ \mathbb{O}_2(x_1,x_2) &:= \Theta(x_1,x_2),\\ \mathbb{O}_s(x_1,\dots,x_s) &:= \sum_{\mu}\frac{\partial \mathbb{O}_{s-1}}{\partial\theta_\mu}\frac{\partial f(x_s)}{\partial\theta_\mu}, \qquad s\geq 3,\end{aligned} \tag{97}$$

它们服从相应的耦合常微分方程层级：

$$\frac{d\mathbb{O}_{s,t}(x_1,\dots,x_s)}{dt} = -\sum_{\alpha\in\mathcal{D}} R_{\alpha,t}\mathbb{O}_{s+1,t}(x_1,\dots,x_s,x_\alpha). \tag{98}$$

该方程组具有引人注目的结构，从较高层面看令人联想到统计物理中的 BBGKY（Bogoliubov–Born–Green–Kirkwood–Yvon）层级，我们或可将 $x_1, x_2, \dots$ 解释为相互作用的粒子。虽然这里不进一步追究这种对应，但我们指出，自然的物理约束可以使 BBGKY 层级闭合。类似地，要进一步推进，我们必须为这个深度神经网络动力学方程组寻找某种自然的闭合方式。

文献 [15] 推导发现，“更高阶”（指 s）变量 $\mathbb{O}_s$ 在初始化时具有受宽度倒数抑制的自然尺度（对于选取特定非线性函数的深度神经网络）。具体地，对不同于 $\mathbb{O}_s$ 变量的函数 $F_t(x)$，

$$\mathbb{E}_{\theta_t}[\mathbb{O}_{s,t}(x_1,\dots,x_s)F_t(x)] = \begin{cases} O(n^{-(s-2)/2}), & s \text{ 为偶数},\\ O(n^{-(s-1)/2}), & s \text{ 为奇数}.\end{cases} \tag{99}$$

在 NTK 参数化的随机初始化神经网络中，可以通过计数求和及导数的数量来推导这些期望值的标度。（对于深度线性网络，这将是 Wick 定理的一次直接应用。）期望值的标度在训练期间也成立，因为 $\mathbb{O}_s$ 变量的动力学修正由更大 s 的受抑制变量控制。如果训练损失（与 $R_{\alpha,t}$ 变量的贡献相关）下降得足够快，那么与初始化时的标度相比，期望值标度的变化可以忽略。（特别地，我们从恰好可解的极限知道，在该极限附近，训练损失及因而 R_α 随时间指数下降，在 n 较大时进一步抑制修正的累积。）

因此，我们发现，在耦合常微分方程中，高阶变量 $\mathbb{O}_s$ 对网络函数 $f_t(x)$ 动力学的贡献受到抑制；当宽度 n 很大且梯度流有效时，可以在有限 s 处截断层级。

3.2.2 含有限宽度主导阶 $1/n$ 修正的动力学

由期望值标度 (99)，有 $\mathbb{O}_3, \mathbb{O}_4 \sim O(1/n)$，而 $\mathbb{O}_{s\geq 5} \sim O(1/n^2)$。我们希望计算精确到 $1/n$、但舍去更高阶项的有限宽度神经网络动力学。由于我们关注的是对*动力学*的修正，而非*初始化*时即已存在的无限宽与有限宽差异，我们将以大但有限 n 的随机初始化神经网络为起点积分这些常微分方程。因此本节中的 $\mathbb{O}_{s,0}$ 变量（尤其是 NTK Θ_0）指随机初始化的*有限宽度*网络中这些变量的初值。

现在，由于

$$\frac{d\mathbb{O}_{4,t}(\cdot)}{dt} = -\sum_{\alpha\in\mathcal{D}} R_{\alpha,t}\mathbb{O}_{5,t}(\cdot,x_\alpha) \sim O\left(\frac{1}{n^2}\right), \tag{100}$$

根据平均值的标度，我们令右端为零，取 $\mathbb{O}_{4,t}(\cdot) = \mathbb{O}_{4,0}(\cdot)$，即等于其初值。（这里用 $\cdot$ 代替等式两侧相同的一组参数。）接下来考察该层级中的前一个方程：

$$\frac{d\mathbb{O}_{3,t}(\cdot)}{dt} \approx -\sum_{\alpha\in\mathcal{D}} \underbrace{\big(f_t(x_\alpha)-y_\alpha\big)}_{a_0+a_1/n+a_2/n^2+\cdots}\ \underbrace{\mathcal{O}_{4,t}(\cdot,x_\alpha)}_{b_1/n+b_2/n^2+\cdots}. \tag{101}$$

我们认为右端变量具有宽度倒数的幂级数展开（系数分别为 $\{a_i\},\{b_i\}$），残差与 $\mathbb{O}_{4,t}$ 的展开分别从 $1/n^0$ 和 $1/n$ 开始。因此，要将 $\mathbb{O}_{3,t}$ 计算到 $O(1/n)$，只需要残差 $R_{\alpha,t}=f_t(x_\alpha)-y_\alpha$ 的 $1/n^0$ 贡献；这正是第二讲 (89) 推导的随时间指数变化的恰好可解动力学（尽管这里将这些量解释为来自随机初始化的有限宽网络）。代入并积分后得到

$$\mathbb{O}_{3,t}(\tilde{x})=\mathbb{O}_{3,0}(\tilde{x})-\sum_{\alpha,\beta\in\mathcal{D}}\mathbb{O}_{4,0}(\tilde{x},x_\alpha)[\Theta_0^{-1}]_{\alpha,\beta}(1-e^{-t\Theta_0})_{\alpha,\beta}\big(f_0(x_\beta)-y_\beta\big), \tag{102}$$

其中用 $\tilde{x}=(x_1,x_2,x_3)$ 简记三个样本变量，并显式标出了所需的 Θ_0^{-1} 与 $e^{-t\Theta_0}$ 的矩阵元。注意，由于 $\mathbb{O}_{4,0}$ 的标度，式 (102) 中含时项隐含地按 $\sim 1/n$ 缩放。下一步是利用对 $\mathbb{O}_{3,t}$ 的修正来修正动力学神经切线核。我们将其写作 $\Theta_t=\Theta_0+\Theta_t^{(1)}+O(1/n^2)$，并记住这里复用了记号，$\Theta_0$ 来自随机初始化的有限宽网络。计算 $\Theta_t^{(1)}$ 在解析上可行，因为它需要对指数函数积分；为突出结果的结构，我们在 Θ_0 的本征基中进行计算，其本征值为 $\{\lambda_i\}$，本征向量为 $\{\hat{e}_i\}$：

$$\begin{aligned}
\Theta_t^{(1)}(x_1,x_2)\approx&-\underbrace{\Theta_0^{(1)}(x_1,x_2)}_{=0}-\int_0^t dt'\sum_{\alpha\in\mathcal{D}}\underbrace{\big(f_t(x_\alpha)-y_\alpha\big)}_{a_0+a_1/n+\cdots}\underbrace{\mathbb{O}_{3,t}(x_1,x_2,x_\alpha)}_{c_1/n+c_2/n^2+\cdots}\\
=&-\int_0^t dt'\sum_i\big(\mathbb{O}_{3,0}(\vec{x})\cdot\hat{e}_i\big)e^{-\lambda_i t'}(R_0\cdot\hat{e}_i)\\
&+\int_0^t dt'\sum_{ij}(\hat{e}_i\cdot\mathbb{O}_{4,0}(\vec{x})\cdot\hat{e}_j)\frac{1-e^{-\lambda_j t'}}{\lambda_j}(R_0\cdot\hat{e}_j)e^{-t'\lambda_i}(R_0\cdot\hat{e}_i)\\
=&-\sum_i(\mathbb{O}_{3,0}(\vec{x})\cdot\hat{e}_i)(R_0\cdot\hat{e}_i)\frac{1-e^{-\lambda_i t}}{\lambda_i}\\
&+\sum_{ij}(\hat{e}_i\cdot\mathbb{O}_{4,0}(\vec{x})\cdot\hat{e}_j)\frac{(R_0\cdot\hat{e}_i)(R_0\cdot\hat{e}_j)}{\lambda_j}\\
&\qquad\times\left[\frac{1-e^{-\lambda_i t}}{\lambda_i}-\frac{1-e^{-(\lambda_i+\lambda_j)t}}{\lambda_i+\lambda_j}\right].
\end{aligned} \tag{103}$$

这里用 $\vec{x}=(x_1,x_2)$ 简记两个样本变量，并定义元素为 $R_{\alpha,0}=f_0(x_\alpha)-y_\alpha$ 的向量 R_0；与 $\hat{e}_i,\hat{e}_j$ 的内积意味着对未显式写出的样本自由度缩并（例如 $\mathbb{O}_{3,0}(\vec{x})\cdot\hat{e}_i=\sum_{\alpha\in\mathcal{D}}\mathbb{O}_{3,0}(\vec{x},x_\alpha)(\hat{e}_i)_\alpha$）。

最后，我们可以使用上述神经切线核修正来计算神经网络所学函数的修正。对在训练集 $x_\alpha\in\mathcal{D}$ 上求值的网络函数，得到

$$f_t(x_\alpha)=y_\alpha+\left[e^{-\Theta_0 t}\left(1-\int_0^t dt'\,e^{-\Theta_0 t'}\Theta_{t'}^{(1)}e^{-\Theta_0 t'}\right)(f_0-y)\right]_\alpha+O(1/n^2), \tag{104}$$

类似地可以推导任意点 x 处函数值 $f_t(x)$ 的表达式。

晚期 $t\to\infty$ 时的修正动力学。 在晚期，这些表达式预测以有效核 $\Theta_0+\Theta_\infty^{(1)}$ 控制的时间指数动力学：

$$f(t)\to y+e^{-(\Theta_0+\Theta_\infty^{(1)})t}(f_0-y), \tag{105}$$

其晚期修正为

$$\begin{aligned}
\Theta_\infty^{(1)}:=\lim_{t\to\infty}\Theta_t^{(1)}=&-\sum_i(\mathbb{O}_{3,0}(\vec{x})\cdot\hat{e}_i)\frac{R_0\cdot\hat{e}_i}{\lambda_i}\\
&+\sum_{ij}\frac{(R_0\cdot\hat{e}_i)(R_0\cdot\hat{e}_j)}{\lambda_i(\lambda_i+\lambda_j)}(\hat{e}_i\cdot\mathbb{O}_{4,0}(\vec{x})\cdot\hat{e}_j).
\end{aligned} \tag{106}$$

回顾一下，由于 $\mathbb{O}_{3,0}, \mathbb{O}_{4,0} \sim 1/n$，这些是 $O(1/n)$ 修正。虽然这是特征学习的有效理论描述（即神经切线核偏离其初值 Θ_0），但由于相对于 Θ_0 的值变化很小，我们将其视为“弱”特征学习区间。尽管如此，要推导对不同架构和数据集都保持普适性的特征学习闭式表达式是困难的（除病态情形外，上述推导基本上不依赖模型与数据），因此拥有这样一个表达式供进一步分析是很有意思的。

3.3 大宽度下的大学习率动力学：“弹射”机制

第二讲的主题——无限宽深度神经网络、线性模型、核与高斯过程之间的联系——在梯度下降所用学习率不超过最大值 η_{crit} 时成立。事实上，经验上发现，在比这一值更大的学习率下，大但有限宽度的神经网络也可被优化至收敛 [17]。能否从理论上理解这一范围的某些方面?

为此，考虑一个最简神经网络模型：它由单个无非线性的隐藏层组成，

$$f(x) = \frac{1}{\sqrt{n}} v^{\mathsf{T}} u x, \tag{107}$$

参数为 $v \in \mathbb{R}^n$、$u \in \mathbb{R}^{n \times n_0}$，有 m 个样本 (x_α, y_α)，其中 $x_\alpha \in \mathbb{R}^{n_0}$、$y_\alpha \in \mathbb{R}$；模型在 NTK 参数化下对平方损失使用梯度下降训练。为说明主要特征，然后再回到更一般的情形，我们考虑此模型进一步简化后的设定：取 $n_0 = 1$，只用单一样本 $(x, y) = (1, 0)$ 训练。我们希望理解以下量的动力学：

$$\mathcal{L}_t = \frac{f_t}{2}, \qquad f_t = \frac{1}{\sqrt{n}} v_t^{\mathsf{T}} u_t. \tag{108}$$

参数上的梯度下降动力学为

$$u_{t+1} = u_t - \frac{\eta}{\sqrt{n}} f_t \cdot v_t, \qquad\qquad v_{t+1} = v_t - \frac{\eta}{\sqrt{n}} f_t \cdot u_t, \tag{109}$$

而 NTK 只是一个标量，$\Theta_t(1,1) = \frac{1}{n}(\|u_t\|_2^2 + \|v_t\|_2^2) := \lambda_t$。注意初始化时 $f_0, \Theta_0 \sim O(1)$。我们不在参数空间分析动力学，而在函数空间工作，并类似于第 3.2.1 节中耦合常微分方程层级的构造，写出函数、神经切线核及任何其他动力学变量的演化：

$$f_{t+1} = f_t \left(1 - \eta\lambda_t + \frac{\eta^2 f_t^2}{n}\right), \qquad\qquad \lambda_{t+1} = \lambda_t + \frac{\eta^2 f_t^2}{n}(\eta\lambda_t - 4). \tag{110}$$

令人惊讶的是，对于这个简化设定，我们能够仅用变量 f_t 和 λ_t 精确闭合层级 (98) 的离散时间版本。这与更复杂情形形成对比：在那里需要截断方案才能使系统闭合。

我们分析不同区域中的式 (110)。在 $n \to \infty$ 极限下，

$$f_{t+1} = f_t(1 - \eta\lambda_0), \qquad\qquad \lambda_t = \lambda_0, \tag{111}$$

因此 NTK 为常数，且只要 $|1 - \eta\lambda_0| < 1$，函数值（因而损失）便随时间指数收敛。因此，对于学习率 $\eta < 2/\lambda_0 =: \eta_{\text{crit}}$，得到 NTK 动力学。稍微离开这一极限并保持 $\eta < \eta_{\text{crit}}$，会得到动力学的 $O(1/n)$ 修正，类似于第 3.2 节研究的微扰修正。

对于学习率 $\eta > 4/\lambda_0$，式 (110) 的最后一项为正，使 λ_t 随时间增加并最终与损失一起发散。相比之下，在 $2/\lambda_0 \le \eta \le 4/\lambda_0$ 时存在一个有趣区域。起初函数和损失的幅度开始增大：

$$\begin{aligned} f_{t+1} &= f_t \overbrace{\left(1 - \eta\lambda_t + \frac{\eta^2 f_t^2}{n}\right)}^{t=0 \text{ 时} \ge 1}, \\ \lambda_{t+1} &= \lambda_t + \frac{\eta^2 f_t^2}{n} \underbrace{(\eta\lambda_t - 4)}_{\text{对所有} t \text{ 有} < 0}. \end{aligned} \tag{112}$$

为此注意到，由于 n 很大，我们最初可以忽略 f_t 动力学中的 $\eta^2 f_t^2/n$ 项；又由于 $|1 - \eta\lambda_0| > 1$，$|f_t|$ 会随时间增大。但一旦 $|f_t| \sim O(\sqrt{n})$，λ_t 动力学的第二项就产生 $O(1)$ 的贡献，使 λ_t 能够下降并动态适应大学习率。继而最终有 $|1 - \eta\lambda_t| < 1$，并与 f_t 动力学中的 η^2 项共同使 f_t 和损失收敛到有限值。这里起作用的机制是：局部曲率（主要由 λ_t 刻画）动态适应较大的学习率，优化过程 “弹射” 到参数 u, v 的高维景观中不同于初始条件的区域。使 $|f_t| \sim O(\sqrt{n})$ 的弹射效应发生在时间尺度 $t_* \sim O(\log n)$ 上。

在 $\eta_{\text{crit}} = 2/\lambda_0$ 发生、且随着 $n \to \infty$ 越来越尖锐的 “NTK 区域” 与 “弹射区域” 之间的转变，令人联想到动力学相变。事实上，某些可测量量在此转变附近呈现发散。例如，使损失达到 $O(\epsilon)$ 所需的优化时间 $t_\epsilon(\eta)$ 的行为为

$$t_\epsilon(\eta) \sim \frac{1}{|\eta_{\text{crit}} - \eta|}, \tag{113}$$

在 η_{crit} 附近无论从下方还是上方趋近，指数都是 $\nu = 1$（省略常数）。

这一现象更加令人惊讶之处在于，尽管研究的是大幅简化的模型，经验上却能在各种实际设定中观察到弹射区域，包括不同数据集、神经网络架构和具体优化选择（例如梯度下降中的随机性，以及标准参数化与 NTK 参数化的选择）[17]。再次概述这些经验观察：使用学习率 η 的随机梯度下降及平方损失训练的大宽度深度神经网络呈现三种动力学区域。[5]

1. 当 $\eta \lesssim 2/\lambda_0$ 时，处于 “NTK” 区域，即动力学神经切线核的变化 $\Delta\Theta_t \overset{t\to\infty}{\longrightarrow} 0$ 随 n 增大而消失。我们可以用本讲先前讨论的微扰修正来理解该区域。优化期间损失相当单调地下降。

2. 当 $2/\lambda_0 \lesssim \eta \lesssim \eta_{\max}$ 时，动力学神经切线核在 $n \to \infty$ 时发生不消失的变化：$\Delta\Theta_t \overset{t\to\infty}{\longrightarrow} O(1)$，表现为 “强” 特征学习。这里 $\eta_{\max} = c/\lambda_0$，$c$ 是 $O(1)$ 常数。对最简模型，$c = 4$；虽然在某些非线性深度神经网络中也近似观察到此值，但一般而言 c 是非普适常数。优化过程中损失非单调变化，在训练早期时间尺度 $t \sim O(\log n)$ 上先增大。优化收敛到曲率更平坦的区域（神经切线核本征值受到的影响可证明这一点）。

3. 当 $\eta \ge \eta_{\max}$ 时，优化发散。

回到具有更一般的 m 个样本和维数 n_0 的模型 (107) [17]。参数的梯度下降形式为

$$u_{ia,t+1} = u_{ia,t} - \frac{\eta}{m\sqrt{n}} \sum_{\alpha\in\mathcal{D}} v_{i,t} x_{a\alpha} R_{\alpha,t}, \qquad v_{i,t+1} = v_{i,t} - \frac{\eta}{m\sqrt{n}} \sum_{a,\alpha\in\mathcal{D}} u_{ia,t} x_{a\alpha} R_{\alpha,t}, \tag{114}$$

[5] λ_0 指初始化时神经切线核的最大特征值。

其中仍使用 $R_\alpha = f_\alpha - y_\alpha$。在训练数据上求值的神经切线核的矩阵元为 $\Theta_{\alpha\beta} = \frac{1}{nm}\big(|v|^2 x_\alpha^\mathsf{T} x_\beta + x_\alpha^\mathsf{T} u^\mathsf{T} u x_\beta\big)$。在函数空间的自然变量中追踪动力学（残差 R_α 与 f_α 直接相关）得到

$$\begin{aligned} R_{\alpha,t+1} &= \sum_{\beta\in\mathcal{D}} (\delta_{\alpha\beta} - \eta\Theta_{\alpha\beta,t}) R_{\beta,t} + \frac{\eta^2}{nm}(x_\alpha^\mathsf{T}\zeta_t)(f_t^\mathsf{T} R_t), \\ \Theta_{\alpha\beta,t+1} &= \Theta_{\alpha\beta,t} - \frac{\eta}{nm}\left[(x_\beta^\mathsf{T}\zeta_t) f_{\alpha,t} + (x_\alpha^\mathsf{T}\zeta_t) f_{\beta,t} + \frac{2}{m}(x_\alpha^\mathsf{T} x_\beta)(R_t^\mathsf{T} f_t)\right] \\ &\quad + \frac{\eta^2}{n^2 m}\left[|v_t|^2 (x_\alpha^\mathsf{T}\zeta_t)(x_\beta^\mathsf{T}\zeta_t) + (\zeta_t^\mathsf{T} u_t^\mathsf{T} u_t \zeta_t)(x_\alpha^\mathsf{T} x_\beta)\right], \end{aligned} \tag{115}$$

其中定义向量 $\zeta = \sum_{\alpha\in\mathcal{D}} R_\alpha x_\alpha / m \in \mathbb{R}^{n_0}$。与较简单设定下考察的版本不同，这一离散时间方程组并不闭合，而且考虑类似于 $s \geq 2$ 的 $\mathbb{O}_s$ 高阶变量也不能自然实现其闭合。然而，我们可以近似提取一个与较简单系统 (110) 类似的双变量闭合方程组。考虑神经切线核投影到残差上的动力学：

$$R_t^\mathsf{T}\Theta_{t+1} R_t = R_t^\mathsf{T}\Theta_t R_t + \frac{\eta}{n}\zeta_t^\mathsf{T}\zeta_t\big(\eta R_t^\mathsf{T}\Theta_t R_t - 4 f_t^\mathsf{T} R_t\big). \tag{116}$$

由于函数（或残差）动力学的主导项具有 $\delta_{\alpha\beta} - \eta\Theta_{\alpha\beta_t}$ 的形式，我们或许倾向于近似认为 R_t 会很好地对齐初始化时 Θ 的最大本征向量，记为 $\hat{e}_{\max}$。（尤其在弹射区域，函数和残差指数增长，而这一增长沿 $\hat{e}_{\max}$ 方向发生。）因此，作为一种简单近似，取 $f_t \approx R_t \approx (\hat{e}_{\max}\cdot R_t)\hat{e}_{\max}$。这使我们能够近似地将投影核方程简化为最大 NTK 本征值的方程：

$$\lambda_{t+1} \approx \lambda_t + \frac{\eta}{n}\zeta_t^\mathsf{T}\zeta_t(\eta\lambda_t - 4), \tag{117}$$

它与较简单的式 (110) 类似。因此，我们能够理解，尽管式 (115) 不闭合，它仍包含式 (110) 的机制和普适现象，从而产生不同的神经网络动力学区域。

4 第四讲：Boris Hanin

第四、五讲由 Boris Hanin 主讲。它们延续 Yasaman Bahri 的第一至第三讲的脉络，重点讨论全连接神经网络先验分布的渐近与微扰计算。第四讲推导 NNGP 的微扰修正；第五讲转向专门针对 ReLU 网络的精确先验计算。

4.1 记号对照表

从现在起记号发生变化，汇总如下：

第一至三讲	第四、五讲
$\mathbb{E}[\cdot]$	$\langle\cdot\rangle$
$0 \le \ell < L$	$1 \le \ell < L+1$
$z_i^{l=\ell}(x_\alpha)$	$z_{i;\alpha}^{(\ell)}$
$K^{l=\ell}(x_\alpha, x_\beta)$	$K_{\alpha\beta}^{(\ell)}$
$\phi(\cdot)$（非线性函数）	$\sigma(\cdot)$
σ_b^2, σ_w^2	C_b, C_w

4.2 记号

固定 $L \ge 1$、$n_0, \dots, n_{L+1} \ge 1$ 及 $\sigma : \mathbb{R} \to \mathbb{R}$。我们考虑一个全连接前馈网络，它如下将输入 $x_\alpha \in \mathbb{R}^{n_0}$ 映射为输出 $z_\alpha^{(L+1)} \in \mathbb{R}^{n_{L+1}}$：

$$z_{i;\alpha}^{(\ell+1)} = \begin{cases} b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma(z_{j;\alpha}^{(\ell)}), & \ell \ge 1, \\ b_i^{(1)} + \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha}, & \ell = 0. \end{cases} \tag{118}$$

我们将计算各种高斯积分，使用简记

$$\langle f(z_\alpha) \rangle_{K^{(\ell)}} = \int_{\mathbb{R}} f(z_\alpha) \exp\left[-\frac{z_\alpha^2}{2K_{\alpha\alpha}^{(\ell)}} - \frac{1}{2}\log(2\pi K_{\alpha\alpha}^{(\ell)}) \right] dz_\alpha,$$

更一般地，

$$\langle f(z_\alpha, z_\beta) \rangle_{K^{(\ell)}} = \int_{\mathbb{R}^2} f(z_\alpha, z_\beta) \exp\left[-\frac{1}{2} \sum_{\delta,\gamma \in \{\alpha,\beta\}} (K^{(\ell)})_{\gamma\delta}^{-1} z_\gamma z_\delta - \frac{1}{2}\log\det(2\pi K^{(\ell)}) \right] dz_\alpha dz_\beta,$$

其中 (z_α, z_β) 为均值零、协方差为下式的高斯向量：

$$K^{(\ell)} = \begin{pmatrix} K_{\alpha\alpha}^{(\ell)} & K_{\alpha\beta}^{(\ell)} \\ K_{\alpha\beta}^{(\ell)} & K_{\beta\beta}^{(\ell)} \end{pmatrix}.$$

4.3 主要问题：陈述、答案和动机

4.3.1 主要问题的精确陈述

固定 $L \ge 1$、$n_0, \dots, n_{L+1} \ge 1$、$\sigma : \mathbb{R} \to \mathbb{R}$ 以及常数 $C_b \ge 0, C_W > 0$。假设

$$W_{ij}^{(\ell)} \sim \mathcal{N}(0, C_W/n_{\ell-1}), \qquad b_i^{(\ell)} \sim \mathcal{N}(0, C_b) \qquad \text{彼此独立.} \tag{119}$$

我们希望理解在隐藏层宽度大但有限，即 $n_1, \dots, n_L \simeq n \gg 1$ 时，场

$$x_\alpha \in \mathbb{R}^{n_0} \quad \longmapsto \quad z_\alpha^{(L+1)} \in \mathbb{R}^{n_{L+1}}$$

的分布。

4.4 主要问题的答案

我们将努力说明，$z_\alpha^{(L+1)}$ 的统计性质由以下因素决定：

- 非线性函数 σ 的普适类（由具有该非线性函数的无限宽网络在大 ℓ 下的行为确定）；
- 有效深度（或有效复杂度）$1/n_1 + \cdots + 1/n_L \simeq L/n$。

具体来说，我们将看到：

- 在初始化时，L/n 同时度量神经元之间的相关性及数值与梯度的涨落（本讲）。
- L/n 度量偏离 NTK 区域的程度：一步梯度下降引起的 NTK 变化按 L/n 缩放。因此，（冻结的）NTK 区域对应有效深度 L/n 趋于零的情形。此外，以训练开始时网络 Jacobian 的变化程度来衡量特征学习，其程度也由 L/n 度量（下一讲）。
- L/n 度量特征学习的程度，其含义是训练结束时整个网络函数按 NTK 答案加 L/n 再加大小为 $(L/n)^2$ 的误差缩放（见文献 [10] 的第 ∞ 章）。

这提示了一个有趣的相图，见图 2。

4.5 动机

在尝试使第 4.4 节中的答案精确化之前，我们给出研究主要问题的几个动机：

1. 第一个动机以机器学习为中心。在实践中使用神经网络需要选择许多超参数，包括：
   - 宽度 n；
   - 深度 L；
   - 非线性函数 σ；
   - 初始化方差 C_b, C_W；
   - 学习率 η；
   - 批量大小 $|\mathcal{B}|$；
   - （ℓ_1 或 ℓ_2）正则化强度。

   直接搜索超参数非常昂贵。通过研究随机网络，我们可以理解这些超参数以哪些组合出现在 $z_\alpha^{(L+1)}$ 的分布中；尤其可以了解如何协调地选择它们，使得在 L, n 和训练步数很大时 $z_\alpha^{(L+1)}$ 非退化（比如在训练开始附近）。

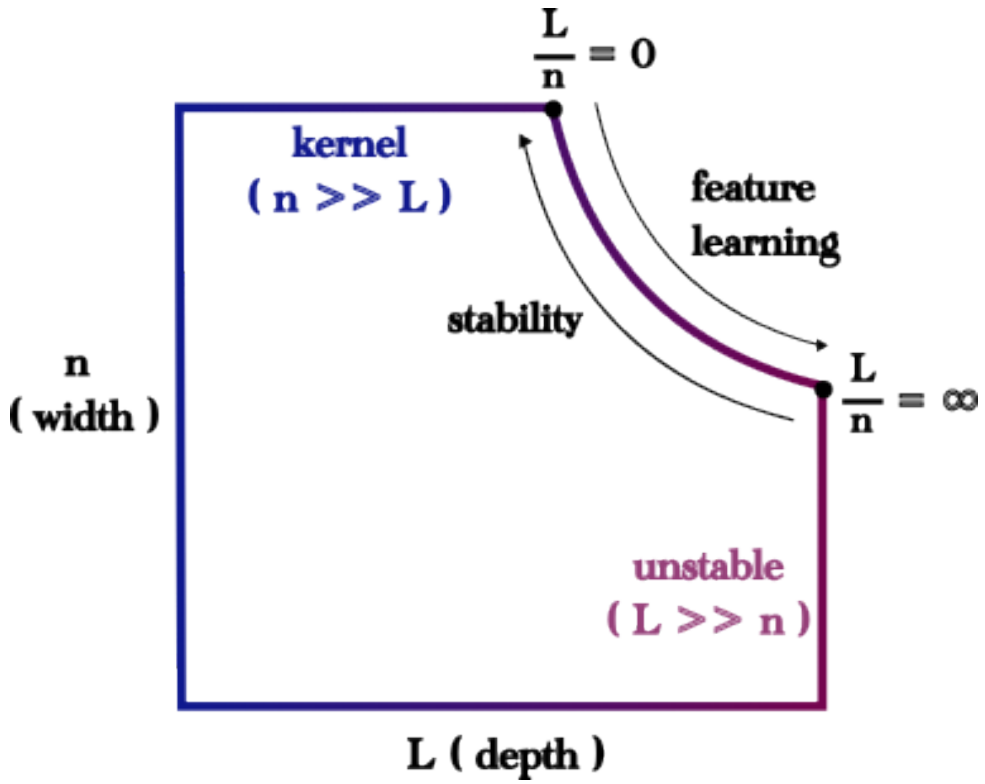


图 2: 采用 NTK 初始化的全连接网络的部分相图。**译注：**横轴为深度 L，纵轴为宽度 n；kernel 表示核区域，feature learning 表示特征学习，stability 表示稳定性，unstable 表示不稳定区域；图中还标示 $n \gg L$、$L \gg n$ 以及 L/n 的极限。

2. 第二个动机是数学或理论方面的。随机全连接神经网络是随机矩阵乘积的非线性推广。事实上，取 $n_\ell \equiv n$、$\sigma(t) = t$、$C_b = 0, C_W = 1$，则

$$z_\alpha^{(L+1)} = W^{(L+1)} \cdots W^{(1)} x_\alpha$$

只是 $L+1$ 个独立同分布随机矩阵之积的一个线性统计量。随机矩阵乘积随处可见。当 $L = 1$（或更一般地，L 固定且有限）而 $n \to \infty$ 时，这类似于 Wigner（或 Wishart）随机矩阵理论。相比之下，当 n 固定而 $L \to \infty$ 时，这是对随机动力系统长时间行为的研究，属于乘法遍历定理的范畴，例如用于研究一维 Anderson 局域化。关键是这两个区域非常不同，而当 n, L 都很大时会发生什么，即便对这个随机矩阵模型而言也相对缺乏理解。

3. 最后一个动机再次以机器学习为中心。正如 Yasaman 在讲义中所展示的，当 L 固定且 $n \to \infty$ 时，具有初始化 (119) 的全连接网络处于（冻结的）NTK 区域。在这种情形下，整个训练动力学（至少对于学习率无穷小的均方误差）由初始化行为决定。因此，是神经网络在初始化时的性质使我们能够描述泛化行为和训练动力学。特别地，通过直接对训练结束时做微扰理论，就可以理解近 NTK 区域中的训练；该区域中 NTK 变化到 $1/n$（实际上是 L/n）阶，参见文献 [10] 的第 ∞ 章。

4.6 L/n 出现的直观理解

在解释如何计算随机神经网络统计性质的有限宽度修正之前，我们先阐述一个简单直觉：为什么出现的是 L/n 而非 L 与 n 的其他组合。为此考虑非常简单的随机矩阵乘积情形

$$n_\ell \equiv n, \qquad \sigma(t) = t, \qquad C_b = 0, \quad C_W = 1,$$

从而

$$z_\alpha^{(L+1)}(x) = W^{(L+1)} \cdots W^{(1)} x_\alpha, \qquad W_{ij}^{(\ell)} \sim \mathcal{N}(0, 1/n) \quad \text{独立同分布.}$$

为方便起见，假设 $\|x_\alpha\|$ 有界。我们尝试理解与矩阵乘积关联的一个可能最简单的随机变量：

$$X_{n,L+1} := \|z_\alpha^{(L+1)}\|.$$

为理解其分布，回顾对任意 $k \geq 1$，具有 k 个自由度的卡方随机变量由下式给出：

$$\chi_k^2 \stackrel{d}{=} \sum_{j=1}^{k} X_j^2, \qquad X_j \sim \mathcal{N}(0,1) \quad \text{独立同分布.}$$

还要回顾，对于任意单位向量 u，若矩阵 $W \in \mathbb{R}^{n \times n}$ 的元素 $W_{ij} \sim \mathcal{N}(0, 1/n)$，则

$$Wu \stackrel{d}{=} \mathcal{N}(0, n^{-1} I_n), \qquad \|Wu\|^2 \stackrel{d}{=} n^{-1} \chi_n^2, \qquad \|Wu\| \perp \frac{Wu}{\|Wu\|},$$

其中 $\perp$ 表示条件独立。为使用这一事实，将其写为

$$\begin{aligned} X_{n,L+1} &= \|W^{(L+1)} \cdots W^{(1)} x_\alpha\| \\ &= \left\| W^{(L+1)} \cdots W^{(2)} \frac{W^{(1)} x_\alpha}{\|W^{(1)} x_\alpha\|} \right\| \|W^{(1)} x_\alpha\|. \end{aligned}$$

注意

$$\left(\frac{1}{n}\chi_n^2\right)^{1/2} \overset{d}{=} \|W^{(1)}x_\alpha\| \perp \frac{W^{(1)}x_\alpha}{\|W^{(1)}x_\alpha\|} \in S^{n-1}.$$

因此，上述表示事实上使我们可以把 $X_{n,L+1}$ 写成两个独立项的乘积！如此继续，就得到以下分布等式：

$$X_{n,L+1} \overset{d}{=} \exp\left[\sum_{\ell=1}^{L+1} Y_\ell\right], \qquad Y_\ell \sim \frac{1}{2}\log\left(\frac{1}{n}\chi_n^2\right) \quad \text{独立同分布.}$$

习题。证明

$$\mathbb{E}\left[\frac{1}{2}\log\left(\frac{1}{n}\chi_n^2\right)\right] = -\frac{1}{4n} + O(n^{-2}), \qquad \mathrm{Var}\left[\frac{1}{2}\log\left(\frac{1}{n}\chi_n^2\right)\right] = \frac{1}{4n} + O(n^{-2}).$$

因此，我们看到

$$X_{n,L+1} \underset{L\gg 1}{\overset{d}{\approx}} \exp\left[\mathcal{N}\left(-\frac{L}{4n}, \frac{L}{4n}\right)\right],$$

并且在每一层取大的 n 会使每个 Y_j 试图接近 1，但存在大小为 $1/n$ 的误差。当有 L 个这样的误差时，总误差的大小为 L/n 阶。

4.7 Yasaman 第一至第三讲的总结

我们用一个较长的定理概括 Yasaman 讲义的一部分。为此，回顾自由场（即高斯场）是指在任意有限个点上场的联合分布都是高斯分布的场。因此，自由场完全由其一点与两点函数决定。

定理 4.1 (固定深度和无限宽网络的 GP 与 NTK 区域)**.** 固定 L, n_0, n_{L+1}, σ。假设在训练开始时按式 (119) 初始化。

(i) **初始化时的 *GP***。当 $n_1, \ldots, n_L \to \infty$，场 $x \mapsto z^{(L+1)}(x)$ 依分布弱收敛到一个自由（高斯）场，其一点函数为零，

$$\lim_{n_1,\ldots,n_L\to\infty} \mathbb{E}[z_{i;\alpha}^{(L+1)}] = 0,$$

两点函数在神经元间因子化：

$$\lim_{n_1,\ldots,n_L\to\infty} \mathrm{Cov}(z_{i;\alpha}^{(L+1)}, z_{j;\beta}^{(L+1)}) = \delta_{ij} K_{\alpha\beta}^{(L+1)}.$$

此外，两点函数由以下递推关系给出：

$$K_{\alpha\beta}^{(\ell+1)} = \begin{cases} C_b + C_W \langle \sigma(z_\alpha)\sigma(z_\beta)\rangle_{K^{(\ell)}}, & \ell \geq 1, \\ C_b + \frac{C_W}{n_0} x_\alpha \cdot x_\beta, & \ell = 0. \end{cases} \tag{120}$$

若通过“调节到临界性”选择 C_b, C_W（例如 $ReLU$ 取 $C_b = 0, C_W = 2$，或 tanh 取 $C_b = 0, C_W = 1$），其含义为

$$\begin{aligned}
&\exists K_* \geq 0 \quad \text{使得} \quad K_* = C_b + C_W \langle \sigma^2 \rangle_{K_*}, \\
&\left. \frac{\partial K^{(\ell+1)}_{\alpha\alpha}}{\partial K^{(\ell)}_{\alpha\alpha}} \right|_{K^{(\ell)}_{\alpha\alpha} = K_*} = \chi^{(\ell)}_{\|;\alpha} = \frac{C_W}{2} \langle \partial^2 \sigma^2 \rangle_{K_*} = 1, \\
&\left. \frac{\partial K^{(\ell+1)}_{\alpha\beta}}{\partial K^{(\ell)}_{\alpha\beta}} \right|_{K^{(\ell)}_{\alpha\alpha} = K^{(\ell)}_{\beta\beta} = K^{(\ell)}_{\alpha\beta} = K_*} = \chi^{(\ell)}_{\perp} = C_W \langle (\sigma')^2 \rangle_{K_*} = 1,
\end{aligned}$$

则

$$K^{(\ell)}_{\alpha\alpha} \simeq \ell^{-\delta_1}, \qquad \delta_1 \in [0, 1],$$

以及

$$\mathrm{Corr}^{(\ell)}_{\alpha\beta} := \frac{K^{(\ell)}_{\alpha\beta}}{(K^{(\ell)}_{\alpha\alpha} K^{(\ell)}_{\beta\beta})^{1/2}} \simeq 1 - C_\sigma \ell^{-\delta_2}, \qquad \delta_2 \in [1, 2]. \tag{121}$$

- **小学习率、均方误差优化与线性模型的等价性**。若 $\theta = \{W^{(\ell)}, b^{(\ell)}\}$ 按式 (119) 初始化为 θ_0，并对固定数据集上的经验均方误差采用梯度流（或学习率如 $n^{-1/2}$ 的梯度下降）优化，则当 $n_1, \ldots, n_L \to \infty$ 时，优化等价于先作线性化

$$z^{(L+1)}_\alpha(\theta) \longmapsto z^{(L+1)}_\alpha(\theta_0) + \nabla_\theta z^{(L+1)}_\alpha(\theta_0)(\theta - \theta_0),$$

然后对同一损失执行梯度流。相应的（神经切线）核

$$\Theta^{(L+1)}_{\alpha\beta} := \nabla_\theta z^{(L+1)}_\alpha(\theta_0)^T \nabla_\theta z^{(L+1)}_\beta(\theta_0) \in \mathbb{R}^{n_{L+1} \times n_{L+1}}$$

满足类似于式 (120) 的递推关系。

4.8 神经元间相关性与非高斯涨落的形式化

为陈述本讲的主要结果，定义归一化的连通四点函数：

$$\begin{aligned}
\kappa^{(\ell)}_{4;\alpha} &= \frac{1}{3} \kappa(z^{(\ell)}_{i;\alpha}, z^{(\ell)}_{i;\alpha}, z^{(\ell)}_{i;\alpha}, z^{(\ell)}_{i;\alpha}) \\
&= \frac{1}{3} \left(\mathbb{E}[(z^{(\ell)}_{i;\alpha})^4] - 3\mathbb{E}[(z^{(\ell)}_{i;\alpha})^2]^2 \right).
\end{aligned}$$

注意，$\kappa^{(\ell)}_{4;\alpha}$ 同时刻画涨落

$$\mathrm{Var}[(z^{(\ell)}_{i;\alpha})^2] = 3\kappa^{(\ell)}_{4;\alpha} + 2\mathbb{E}[(z^{(\ell)}_{i;\alpha})^2]^2,$$

和非高斯性（即若 $z^{(\ell)}_{i;\alpha}$ 为高斯变量，则 $\kappa^{(\ell)}_{4;\alpha} = 0$）。

习题。证明

$$\kappa^{(\ell)}_{4;\alpha} := \mathrm{Cov}((z^{(\ell)}_{i;\alpha})^2, (z^{(\ell)}_{j;\alpha})^2),$$

从而可将 $\kappa_{4;\alpha}^{(\ell)}$ 理解为神经元间相关性的度量。

由于 $n_1,\dots,n_L\to\infty$ 时神经元独立且为高斯变量，故

$$\lim_{n_1,\dots,n_{\ell-1}\to\infty}\kappa_{4;\alpha}^{(\ell)}=0.$$

本讲的主要目的是得到以下对 $\kappa_{4;\alpha}^{(\ell)}$ 的刻画。

定理 4.2. 固定 L,n_0,n_{L+1},σ。假设权重和偏置按式 (119) 选取，且 $n_1,\dots,n_L\simeq n\gg 1$。四点函数为 $O(n^{-1})$，并满足递推关系

$$\kappa_4^{(\ell+1)}=\frac{C_W^2}{n_\ell}\operatorname{Var}_{K^{(\ell)}}[\sigma^2]+(\chi_{\|;\alpha}^{(\ell)})^2\kappa_4^{(\ell)}+O(n^{-2}).$$

因此，在临界性与均匀宽度（$n_\ell=n$）下，有

$$\frac{\kappa_{4;\alpha}^{(L+1)}}{(K_{\alpha\alpha}^{(L+1)})^2}=C_\sigma\frac{L}{n}+O_{L,\sigma}(n^{-2}).$$

此外，对任意固定 $m\geq 1$ 和任何“合理”的函数 $f:\mathbb{R}^m\to\mathbb{R}$，可写成

$$\begin{aligned}\mathbb{E}[f(z_{i;\alpha}^{(\ell)},\,i=1,\dots,m)]&=\langle f(z_{i;\alpha},\,i=1,\dots,m)\rangle_{G^{(\ell)}}\\&\quad+\frac{\kappa_4^{(\ell+1)}}{8}\left\langle\left(\sum_{j=1}^m\partial_{z_{j;\alpha}}^4+\sum_{\substack{j_1,j_2=1\\ j_1\neq j_2}}^m\partial_{z_{j_1;\alpha}}^2\partial_{z_{j_2;\alpha}}^2\right)f(z_{i;\alpha},\,i=1,\dots,m)\right\rangle_{K^{(\ell)}}\\&\quad+O(n^{-2}).\end{aligned}$$

其中 $G^{(\ell)}$ 是经过修饰的两点函数：

$$G_{\alpha\beta}^{(\ell)}=\mathbb{E}[z_{i;\alpha}^{(\ell)}z_{i;\beta}^{(\ell)}]=K_{\alpha\beta}^{(\ell)}+O(n^{-1}).$$

这个定理最初在 Yaida 的开创性论文 [18] 中用物理学方法推导。随后文献 [10] 第四章再次以物理学层面的严格性推导了它。最后，文献 [19] 以一种略有不同、更加数学化的方法推导了它。

4.9 定理 4.2 的证明

4.9.1 一些背景

为了研究一般非高斯随机向量 $z=(z_1,\dots,z_m)$，我们将研究其特征函数

$$\widehat{p}_z(\xi):=\mathbb{E}[e^{-iz\cdot\xi}]=\int_{\mathbb{R}^m}e^{-i\sum_{j=1}^m z_j\xi_j}p(z)\,dz.$$

它的用途在于：

1. 对任何合理的 f，通过 Fourier 变换，可以用特征函数写出 $f(z)$ 的期望：

$$\mathbb{E}[f(z)]=\int_{\mathbb{R}^m}f(z)p(z)\,dz=\int_{\mathbb{R}^m}\widehat{f}(\xi)\widehat{p}_z(\xi)\,d\xi.$$

2. 方差为零的高斯分布 K 具有最简单的特征函数：[6]

$$z \sim \mathcal{N}(0, K) \quad \Rightarrow \quad \widehat{p}_z(\xi_1, \dots, \xi_m) = \exp\left[-\frac{1}{2}\sum_{j_1, j_2=1}^{m} K_{j_1 j_2}\xi_{j_1}\xi_{j_2}\right].$$

3. $\widehat{f}(\xi)$ 乘以 ξ 对应于微分：

$$\xi_j \widehat{f}(\xi) = \widehat{-i\partial_j f}(\xi).$$

我们需要以下命题。

命题 4.3. 设 $W = (W_1, \dots, W_n) \sim N(\mu, \Sigma)$。那么，对任意与它独立（例如常数）的矩阵 $A \in \mathbb{R}^{k\times n}$，有

$$AW \sim \mathcal{N}(A\mu, A\Sigma A^T).$$

4.9.2 第一步：归结为集体可观测量

定义。对任何 $f : \mathbb{R}^m \to \mathbb{R}$，称

$$\mathcal{O}_f^{(\ell)} = \frac{1}{n_\ell}\sum_{j=1}^{n_\ell} f(z_{j;\alpha}^{(\ell)},\, \alpha = 1, \dots, m)$$

为集体可观测量。

集体可观测量在我们的分析中起关键作用。事实上，第一步是用这类对象改写定理 4.2 中的所有量。固定任意 $m \geq 1$，有

$$\mathbb{E}[f(z_{i;\alpha}^{(\ell+1)},\, i = 1, \dots, m)] = \int_{\mathbb{R}^m} \widehat{f}(\xi)\mathbb{E}\left[\exp\left(-i\sum_{j=1}^{m}\xi_j z_{j;\alpha}^{(\ell+1)}\right)\right] d\xi.$$

我们先应用命题 4.3 简化 $(z_{i;\alpha}^{(\ell+1)},\, i = 1, \dots, m)$ 的特征函数。

引理 4.4. 在给定 $z_\alpha^{(\ell)}$ 的条件下，$(z_\alpha^{(\ell+1)})_{i=1}^{n_{\ell+1}}$ 是均值为零、协方差为 $\Sigma_\alpha^{(\ell)} I$ 的高斯变量，其中

$$\Sigma_\alpha^{(\ell)} = C_b + \frac{C_W}{n_\ell}\sum_{j=1}^{n_\ell}\sigma(z_{j;\alpha}^{(\ell)})^2$$

是集体可观测量。特别地，对每个 $\xi = (\xi_1, \dots, \xi_m)$，有

$$\mathbb{E}\left[e^{-i\sum_{i=1}^m \xi_i z_{i;\alpha}^{(\ell+1)}}\right] = \mathbb{E}\left[e^{-\frac{1}{2}\|\xi\|^2\Sigma_\alpha^{(\ell)}}\right],$$

并且

$$\kappa_4^{(\ell+1)} = \mathrm{Var}[\Sigma_\alpha^{(\ell)}].$$

[6]译注：此处措辞依原文保留；结合紧随其后的 $z \sim \mathcal{N}(0, K)$，应核查原文是否意为均值为零、协方差为 K 的高斯分布。

证明. 有

$$z_{i;\alpha}^{(\ell+1)} = (\sigma(z_\alpha^{(\ell)}) \quad 1)(W^{(\ell+1)} \quad b^{(\ell+1)})^T.$$

因此，给定 $\sigma(z_\alpha^{(\ell)})$ 时，$(z_{i;\alpha}^{(\ell+1)})_{i=1}^{n_{\ell+1}}$ 是均值为零、相互独立同分布的高斯变量，且

$$\Sigma_\alpha^{(\ell)} = \mathbb{E}[(z_{i;\alpha}^{(\ell+1)})^2] = C_b + \frac{C_W}{n_\ell}\sum_{j=1}^{n_\ell}\sigma(z_{j;\alpha}^{(\ell)})^2.$$

特别地，

$$\mathbb{E}\left[e^{-i\sum_{j=1}^m \xi_j z_{j;\alpha}^{(\ell+1)}}\right] = \mathbb{E}\left[\mathbb{E}\left[e^{-i\sum_{j=1}^m \xi_j z_{ij\alpha}^{(\ell+1)}}\middle| z_\alpha^{(\ell)}\right]\right] = \mathbb{E}\left[e^{-\frac{1}{2}\|\xi\|^2\Sigma_\alpha^{(\ell)}}\right].$$

□

因此，对任意合理的 f，我们得到

$$\mathbb{E}[f(z_{i;\alpha}^{(\ell+1)}, i = 1, \dots, m)] = \int_{\mathbb{R}^m} \widehat{f}(\xi)\mathbb{E}[e^{-\frac{1}{2}\|\xi\|^2\Sigma_\alpha^{(\ell)}}]d\xi.$$

4.10 第二步：将自平均可观测量 $\Sigma_\alpha^{(\ell)}$ 分解为均值与涨落

由于 $\Sigma_\alpha^{(\ell)}$ 是集体可观测量，考虑下列量是合理的：

$$G_\alpha^{(\ell)} := \mathbb{E}[\Sigma_\alpha^{(\ell)}], \qquad \Delta_\alpha^{(\ell)} := \Sigma_\alpha^{(\ell)} - \mathbb{E}[\Sigma_\alpha^{(\ell)}].$$

标量 $G_\alpha^{(\ell)}$ 有时称为修饰的两点函数。

习题。对任意具有以下形式的可观测量

$$\mathcal{O}_f^{(\ell)} = \frac{1}{n_\ell}\sum_{j=1}^{n_\ell} f(z_{j;\alpha}^{(\ell)}),$$

证明

$$\mathbb{E}\left[\prod_{j=1}^q \left(\mathcal{O}_{f_j}^{(\ell)} - \mathbb{E}[\mathcal{O}_{f_j}^{(\ell)}]\right)\right] = O_{q,f_j,\ell,\sigma}\left(n^{-\lceil q/2\rceil}\right).$$

提示：分几步进行。

(a) 首先在 $\ell = 1$ 时验证。由于第一层神经元独立，这一步很简单。

(b) 然后假设 σ 是多项式，并证明：若已知结果在第 ℓ 层成立，则它在第 $\ell+1$ 层也成立。这一步不太困难，但需要一些记账工作。

(c) 证明完整问题可以归结到多项式激活函数的情形。这一步有些微妙。

4.11 第三步：按中心化集体可观测量的幂展开

有

$$\begin{aligned}\mathbb{E}[f(z_{i;\alpha}^{(\ell)},\, i=1,\dots,m)] &= \int_{\mathbb{R}^{n_m}} \widehat{f}(\xi)\mathbb{E}[e^{-\frac{1}{2}\|\xi\|^2\Sigma_\alpha^{(\ell)}}]d\xi \\ &= \int_{\mathbb{R}^{n_m}} \widehat{f}(\xi)e^{-\frac{1}{2}\|\xi\|^2 G_\alpha^{(\ell)}}\mathbb{E}[e^{-\frac{1}{2}\|\xi\|^2\Delta_\alpha^{(\ell)}}]d\xi.\end{aligned}$$

应用上面的习题，实际上可以做 Taylor 展开，得到 $1/n$ 的幂级数展开：

$$\mathbb{E}[e^{-\frac{1}{2}\|\xi\|^2\Delta_\alpha^{(\ell)}}] = \sum_{q\geq 0}\frac{(-1)^q}{2^q q!}\|\xi\|^{2q}\mathbb{E}[(\Delta_\alpha^{(\ell)})^q] = 1+\frac{1}{8}\|\xi\|^4\mathbb{E}[(\Delta_\alpha^{(\ell)})^2]+O(n^{-2}).$$

综合起来得到

$$\mathbb{E}[f(z_{i;\alpha}^{(\ell)},\, i=1,\dots,m)] = \int_{\mathbb{R}^{n_m}}\left(1+\frac{1}{8}\|\xi\|^4\mathbb{E}[(\Delta_\alpha^{(\ell)})^2]\right)\widehat{f}(\xi)e^{-\frac{1}{2}\|\xi\|^2 G_\alpha^{(\ell)}}d\xi + O(n^{-2}).$$

特别地，得到

$$\mathbb{E}[f(z_{i;\alpha}^{(\ell)},\, i=1,\dots,m)] = \langle f\rangle_{G_\alpha^{(\ell)}} + \frac{1}{8}\mathbb{E}[(\Delta_\alpha^{(\ell)})^2]\left\langle\left(\sum_{j=1}^m \partial^2_{z_{j;\alpha}^{(\ell)}}\right)^2 f\right\rangle_{G_\alpha^{(\ell)}} + O(n^{-2}).$$

习题。证明

$$\langle f\rangle_{G_\alpha^{(\ell)}} = \langle f\rangle_{K_{\alpha\alpha}^{(\ell)}} + O(n^{-1}).$$

提示：定义 $S_\alpha^{(\ell)} := G_\alpha^{(\ell)} - K_{\alpha\alpha}^{(\ell)}$。我们已经知道 $\mathbb{E}[(\Delta_\alpha^{(\ell)})^2] = O(n^{-1})$。现在利用上述微扰展开得到 $S_\alpha^{(\ell)}$ 的递推关系，并检验其解为 $O(n^{-1})$ 阶。

4.12 第四步：将 $k_{4;\alpha}^{(\ell+1)}$ 与修饰的两点函数联系起来并得到其递推

回顾引理 4.4，我们看到

$$k_{4;\alpha}^{(\ell+1)} = \mathbb{E}[(\Delta_\alpha^{(\ell)})^2].$$

此外，

$$\mathbb{E}[(\Delta_\alpha^{(\ell)})^2] = \frac{1}{n_\ell}\mathbb{E}[(X_{1;\alpha}^{(\ell)})^2] + \left(1-\frac{1}{n_\ell}\right)\mathbb{E}[X_{1;\alpha}^{(\ell)}X_{2;\alpha}^{(\ell)}],$$

其中

$$X_{j;\alpha}^{(\ell)} := C_W\left(\sigma(z_{j;\alpha}^{(\ell)})^2 - \mathbb{E}[\sigma(z_{j;\alpha}^{(\ell)})^2]\right).$$

应用第三步的结果（及前面的习题）得到

$$\begin{aligned}\frac{1}{n_\ell}\mathbb{E}[(X_{1;\alpha}^{(\ell)})^2] &= \frac{C_W^2}{n_\ell}\left\langle\left(\sigma^2 - \langle\sigma^2\rangle_{K_{\alpha\alpha}^{(\ell)}}\right)^2\right\rangle_{K_{\alpha\alpha}^{(\ell)}} + O(n^{-2}) \\ &= \frac{C_W^2}{n_\ell}\operatorname{Var}_{K^{(\ell)}}[\sigma^2] + O(n^{-2}).\end{aligned}$$

最后注意

$$0 = \mathbb{E}[X^{(\ell)}_{i;\alpha}] = \langle X^{(\ell)}_{i;\alpha} \rangle_{G^{(\ell)}_{\alpha}} + O(n^{-2}).$$

因此，

$$\begin{aligned}\mathbb{E}[X^{(\ell)}_{1;\alpha} X^{(\ell)}_{2;\alpha}] &= \kappa^{(\ell)}_{4;\alpha} \left\langle \left(\frac{1}{8} \sum_{j=1}^{2} \partial^4_{z_{j;\alpha}} + \frac{1}{4} \partial^2_{z_{1;\alpha}} \partial^2_{z_{2;\alpha}} \right) X^{(\ell)}_{1;\alpha} X^{(\ell)}_{2;\alpha} \right\rangle_{K^{(\ell)}_{\alpha\alpha}} + O(n^{-2}) \\ &= \left(\frac{C_W}{2} \langle \partial^2 \sigma^2 \rangle_{K^{(\ell)}_{\alpha\alpha}} \right)^2 \kappa^{(\ell)}_{4;\alpha} + O(n^{-2}) \\ &= (\chi^{(\ell)}_{\|;\alpha})^2 \kappa^{(\ell)}_{4;\alpha} + O(n^{-2}).\end{aligned}$$

4.13 第五步：求解四点函数递推

本节在

$$\sigma(t) = \mathrm{ReLU}(t) = t \mathbf{1}_{t>0}$$

的特殊情形下，求解四点函数递推：

$$\kappa^{(\ell+1)}_4 = \frac{C_W^2}{n_\ell} \mathrm{Var}_{K^{(\ell)}}[\sigma^2] + (\chi^{(\ell)}_{\|;\alpha})^2 \kappa^{(\ell)}_{4;\alpha} + O(n^{-2}).$$

首先，如 Yasaman 所示，

$$K^{(\ell+1)}_{\alpha\alpha} = C_b + C_W \langle \sigma^2(z_\alpha) \rangle_{K^{(\ell)}_{\alpha\alpha}} = C_b + \frac{C_W}{2} K^{(\ell)}_{\alpha\alpha},$$

$$\chi^{(\ell+1)}_{\|;\alpha} = \frac{\partial K^{(\ell+1)}_{\alpha\alpha}}{\partial K^{(\ell)}_{\alpha\alpha}} = \frac{C_W}{2}.$$

因此仅在 $C_b = 0, C_W = 2$ 时处于临界性。此时有

$$\chi^{(\ell)}_{\|;\alpha} \equiv 1, \qquad K^{(\ell)}_{\alpha\alpha} \equiv \frac{2}{n_0} \|x_\alpha\|^2.$$

于是，

$$\mathrm{Var}_{K^{(\ell)}}[\sigma^2] = \langle \sigma^4 \rangle_{K^{(\ell)}_{\alpha\alpha}} - \langle \sigma^2 \rangle^2_{K^{(\ell)}_{\alpha\alpha}} = \frac{3}{2} (K^{(\ell)}_{\alpha\alpha})^2 - \frac{1}{4} (K^{(\ell)}_{\alpha\alpha})^2 = \frac{5}{4} (K^{(\ell)}_{\alpha\alpha})^2.$$

从而得到

$$\frac{\kappa^{(\ell)}_4}{(K^{(\ell)}_{\alpha\alpha})^2} = \sum_{\ell'=1}^{\ell-1} \frac{5}{n_{\ell'}} + O(n^{-2}).$$

习题。对 $\sigma(t) = \tanh(t)$ 重做此分析，求得当 $n_\ell \equiv n$ 时

$$\frac{\kappa^{(\ell)}_4}{(K^{(\ell)}_{\alpha\alpha})^2} = \frac{2\ell}{3n}(1 + o_\ell(1)) + O_\ell(n^{-2}).$$

提示：应首先推导渐近式

$$K^{(\ell)}_{\alpha\alpha} = \frac{1}{2\ell} + O(\log \ell / \ell^2).$$

用它计算 $\kappa^{(\ell)}_4$ 递推中系数的形式，然后求解该递推的 ℓ 主导阶。

5 第五讲

5.1 引言

与上一讲一样，固定 $L \geq 1$、$n_0, \dots, n_{L+1} \geq 1$ 和 $\sigma : \mathbb{R} \to \mathbb{R}$。我们继续考虑全连接前馈网络，它如下将输入 $x_\alpha \in \mathbb{R}^{n_0}$ 映射为输出 $z_\alpha^{(L+1)} \in \mathbb{R}^{n_{L+1}}$：

$$z_{i;\alpha}^{(\ell+1)} = \begin{cases} \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma(z_{j;\alpha}^{(\ell)}), & \ell \geq 1, \\ \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha}, & \ell = 0. \end{cases} \tag{122}$$

注意我们已将偏置设为零。我们主要关注 $n_1, \dots, n_L \simeq n \gg 1$ 且已调节到临界性的情形：

$$W_{ij}^{(\ell+1)} = \sqrt{\frac{2}{n_\ell}} \widehat{W}_{ij}^{(\ell+1)}, \qquad \widehat{W}_{ij}^{(\ell+1)} \sim \mu, \qquad b_i^{(\ell+1)} = 0,$$

其中 μ 是 $\mathbb{R}$ 上满足以下条件的任意分布：

- μ 关于零对称且没有原子；
- μ 的方差为 1，且更高阶矩有限，但除此之外可以任意。

5.2 目标

本讲的目标是引入一个组合形式体系，以研究单个输入处 ReLU 网络的重要特殊情形：

$$\sigma(t) = \mathrm{ReLU}(t) = t\mathbf{1}_{t>0}, \qquad 0 \neq x_\alpha \in \mathbb{R}^{n_0} \text{ 固定}.$$

主要结果将说明以下内容。

定理 5.1 (元论断)**.** *具有独立同分布随机权重的随机 ReLU 网络在单个输入处的行为恰好可解，并由逆温度*

$$\beta := 5\left(\frac{1}{n_1} + \cdots + \frac{1}{n_L}\right) \simeq \frac{5L}{n}$$

决定。具体地：

- *输入—输出 Jacobian 的元素平方 $(\partial_{x_{p;\alpha}} z_{q;\alpha}^{(L+1)})^2$ 服从逆温度为 β 的对数正态分布：*

$$(\partial_{x_{p;\alpha}} z_{q;\alpha}^{(L+1)})^2 \simeq \exp[\mathcal{N}(-\beta/2, \beta)].$$

  我们很快将推导这个结果。

- *在初始化时、单个输入处求值的 NTK $\Theta_{\alpha\alpha}^{(L+1)}$ 的涨落随 β 指数变化：*

$$\mathbb{E}[\Theta_{\alpha\alpha}^{(L+1)}] \sim L, \qquad \frac{\mathbb{E}[(\Theta_{\alpha\alpha}^{(L+1)})^2]}{\mathbb{E}[\Theta_{\alpha\alpha}^{(L+1)}]^2} \sim \exp(5\beta).$$

- *一步梯度下降导致的 NTK 相对变化为*

$$\frac{\mathbb{E}[\Delta\Theta_{\alpha\alpha}^{(L+1)}]}{\mathbb{E}[\Theta_{\alpha\alpha}^{(L+1)}]} \sim \frac{L}{n}\exp(5\beta).$$

5.3 定理 5.1 证明的形式体系

本节旨在介绍一种组合方法，以理解随机 ReLU 网络在单个输入处的数值所决定的几乎任何统计量。我在文献 [20, 21, 22] 中发展了这一观点。

为解释设定，固定 $L \geq 1$ 及 $n_0, \ldots, n_{L+1} \geq 1$，考虑如下递归定义的随机 ReLU 网络 $x \in \mathbb{R}^{n_0} \mapsto z^{(L+1)}(x) \in \mathbb{R}^{n_{L+1}}$：

$$z^{(\ell+1)}(x) = \begin{cases} W^{(1)}x + b^{(1)} \in \mathbb{R}^{n_1}, & \ell = 0, \\ W^{(\ell+1)}\sigma(z^{(\ell)}(x)) + b^{(\ell+1)} \in \mathbb{R}^{n_{\ell+1}}, & \ell \geq 1. \end{cases}$$

假设 $W^{(\ell)} = (W_{ij}^{(\ell)}, i = 1, \ldots, n_\ell,\, j = 1, \ldots, n_{\ell-1})$ 相互独立：

$$W_{ij}^{(\ell)} := \left(\frac{2}{n_{\ell-1}}\right)^{1/2} \widehat{W}_{ij}^{(\ell)}, \qquad \widehat{W}_{ij}^{(\ell)} \sim \mu \quad \text{独立同分布},$$

其中 μ 是 $\mathbb{R}$ 上满足以下条件的任意固定概率测度：

- μ 相对于 Lebesgue 测度具有密度 $d\mu(x)$；
- μ 关于零对称，即对所有 x 有 $d\mu(x) = d\mu(-x)$；
- μ 的方差为 1，即 $\int_{\mathbb{R}} x^2 d\mu(x) = 1$。

使得单个输入处的 ReLU 网络可以进行专门组合分析的关键结果如下。

命题 5.2 (随机 ReLU 网络底层的精确矩阵模型)**.** *随机 ReLU 网络在初始化时、单个输入处的数值，与丢弃概率 $p = 1/2$ 的深度线性网络依分布相等：*

$$z_\alpha^{(L+1)} \overset{d}{=} W^{(L+1)} D^{(L)} W^{(L)} \cdots D^{(1)} W^{(1)} x_\alpha,$$

其中

$$D^{(\ell)} = \mathrm{Diag}(\xi_1, \ldots, \xi_{n_\ell}), \qquad \xi_i \sim \mathrm{Bernoulli}(1/2).$$

证明概要. 总有

$$z_\alpha^{(L+1)} \overset{d}{=} W^{(L+1)} \widehat{D}_\alpha^{(L)} W^{(L)} \cdots \widehat{D}_\alpha^{(1)} W^{(1)} x_\alpha,$$

其中

$$\widehat{D}_\alpha^{(\ell)} = \mathrm{Diag}(\mathbf{1}_{\{z_{i;\alpha}^{(\ell)} > 0\}},\, i = 1, \ldots, n_\ell).$$

给定 ℓ 的条件下，神经元预激活 $z_{i;\alpha}^{(\ell+1)}$ 相互独立。此外，由于 $W_{ij}^{(\ell+1)}$ 的分布关于零对称，有

$$\mathbf{1}_{\{z_{i;\alpha}^{(\ell+1)} > 0\}} \overset{d}{=} \mathrm{Bernoulli}(1/2).$$

然而，该分布与 $z_\alpha^{(\ell)}$ 独立，因此也是变量 $\mathbf{1}_{\{z_{i;\alpha}^{(\ell+1)} > 0\}}$ 的无条件分布。这证明它们相互独立。最后，将所有网络权重的符号对称化，一方面网络权重的任何偶函数的分布不变，另一方面集合 $\mathbf{1}_{\{z_{i;\alpha}^{(\ell+1)} > 0\}}$ 遍历 $\{0,1\}^{\#\text{神经元}}$ 的所有可能配置。因此它们相互独立。 □

为研究随机 ReLU 网络，我们使用以下记号。

定义 2. *层宽为 $n_0,\dots,n_{L+1}$ 的 ReLU 网络的路径空间为*

$$\Gamma := [n_0]\times\cdots\times[n_{L+1}],$$

其中对任意 $n\geq 1$，$[n]=\{1,\dots,n\}$。路径 $\gamma=(\gamma(0),\dots,\gamma(L+1))\in\Gamma$ 决定权重和预激活：

$$W_\gamma^{(\ell)} := W^{(\ell)}_{\gamma(\ell-1)\gamma(\ell)}, \qquad z_{\gamma;\alpha}^{(\ell)} := z^{(\ell)}_{\gamma(\ell);\alpha}.$$

这些路径有用是因为以下熟知的公式：

$$z_{q;\alpha}^{(L+1)} := \sum_{p=1}^{n_0} x_{p;\alpha}\sum_{\gamma\in\Gamma_{p,q}} W_\gamma^{(\ell+1)}\prod_{\ell=1}^{L} W_\gamma^{(\ell)}\xi_{\gamma;\alpha}^{(\ell)}, \qquad \xi_{\gamma;\alpha}^{(\ell)} := \mathbf{1}_{\{z_{\gamma;\alpha}^{(\ell)}>0\}}. \tag{123}$$

习题。验证此公式成立。

注意，命题 5.2 允许我们假设 $\xi_{\gamma;\alpha}^{(\ell)}\sim$ Bernoulli(1/2) 且独立同分布。

5.4 使用路径表示的梯度公式

本节将以习题形式记录一些梯度公式。

习题。证明

$$\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}} = \sum_{\gamma\in\Gamma_{p,q}} W_\gamma^{(L+1)}\prod_{\ell=1}^{L} W_\gamma^{(\ell)}\xi_{\gamma;\alpha}^{(\ell)}.$$

由此推出，对所有 $x_\alpha\neq 0$，$\partial z_{p;\alpha}^{(L+1)}/\partial x_{q;\alpha}$ 的分布相同。

习题。证明

$$\frac{\partial z_1^{(L+1)}(x)}{\partial \widehat{W}_{ij}^{(\ell)}} = \sum_{p=1}^{n_0} x_p \sum_{\substack{\gamma\in\Gamma_{p,1}\\ \gamma(\ell-1)=j,\,\gamma(\ell)=i}} \left(\frac{C_W}{n_{\ell-1}}\right)^{1/2} \frac{W_\gamma^{(L+1)}\prod_{\ell'=1}^{L} W_\gamma^{(\ell')}\xi_{\gamma;\alpha}^{(\ell')}}{W_{ij}^{(\ell)}},$$

从而还有

$$\begin{aligned}&\mathbb{E}\left[\left(\frac{\partial z_1^{(L+1)}(x)}{\partial \widehat{W}_{ij}^{(\ell)}}\right)^2\right]\\ &= \sum_{p_1,p_2=1}^{n_0} x_{p_1,p_2} \sum_{\substack{\gamma_1,\gamma_2\in\Gamma_{p_1,1},\Gamma_{p_2,1}\\ \gamma_k(\ell-1)=j,\,\gamma_k(\ell)=j,\,k=1,2}} \frac{C_W}{n_{\ell-1}}\mathbb{E}\left[\prod_{k=1}^{2} W_{\gamma_k}^{(L+1)}\frac{\prod_{\ell'=1}^{L} W_{\gamma_k}^{(\ell')}\xi_{\gamma_k;\alpha}^{(\ell')}}{(W_{ij}^{(\ell)})^2}\right].\end{aligned}$$

假设 $n_{L+1}=1$，利用此结果推导对角 NTK 的路径求和公式：

$$\Theta_{\alpha,\alpha}^{(L+1)} = \sum_{\ell=1}^{L+1}\sum_{i=1}^{n_\ell}\sum_{j=1}^{n_{\ell-1}}\left(\frac{\partial z_{1;\alpha}^{(L+1)}}{\partial W_{ij}^{(\ell)}}\right)^2.$$

5.5 推导输入—输出 Jacobian 的 L/n 行为

本节目的是证明

$$\mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^2\right] = \frac{2}{n_0}, \qquad \mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^4\right] = \frac{\text{常数}}{n_0^2}\exp\left[5\sum_{\ell=1}^{L}\frac{1}{n_\ell}+O\left(\frac{L}{n^2}\right)\right].$$

5.5.1 二阶矩计算

从二阶矩开始。我们将分若干步（步数比必要的多）完成，以说明第四阶矩中需要的一般思想。首先注意

$$\mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^2\right] = \mathbb{E}\left[\sum_{\gamma_1,\gamma_2\in\Gamma_{p,q}}\prod_{k=1}^{2} W_{\gamma_k}^{(L+1)}\prod_{\ell=1}^{L} W_{\gamma_k}^{(\ell)}\xi_{\gamma_k;\alpha}^{(\ell)}\right]$$
$$= \sum_{\gamma_1,\gamma_2\in\Gamma_{p,q}}\mathbb{E}\left[\prod_{k=1}^{2} W_{\gamma_k}^{(L+1)}\right]\prod_{\ell=1}^{L}\mathbb{E}\left[\prod_{k=1}^{2} W_{\gamma_k}^{(\ell)}\right]\mathbb{E}\left[\prod_{k=1}^{2}\xi_{\gamma_k;\alpha}^{(\ell)}\right].$$

接下来注意

$$\mathbb{E}\left[\prod_{k=1}^{2}(W_{\gamma_k}^{(\ell)})^2\right] = \frac{C_W}{n_{\ell-1}}\delta_{\gamma_1(\ell-1)\gamma_2(\ell-1)}\delta_{\gamma_1(\ell)\gamma_2(\ell)}.$$

换言之，路径 γ_1,γ_2 在每层都必须 “碰撞”。尤其是由于起点和终点相同，它们在所有层都必须一致。特别地，由于 $\mathbb{E}[\xi_{\gamma;\alpha}^{(\ell)}] = 1/2$，得到

$$\mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^2\right] = \sum_{\gamma\in\Gamma_{p,q}}\frac{2}{n_L}\prod_{\ell=1}^{L}\frac{2}{n_{\ell-1}}\cdot\frac{1}{2} = 2\prod_{\ell=0}^{L}\frac{1}{n_\ell}\sum_{\gamma\in\Gamma_{q,p}} 1.$$

注意 $|\Gamma_{q,p}| = \prod_{\ell=1}^{L} n_\ell$。因此，我们实际上可以改写为

$$\mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^2\right] = \frac{2}{n_0}\mathcal{E}[1],$$

其中 $\mathcal{E}[\cdot]$ 表示对均匀随机路径 $\gamma = (\gamma(0),\ldots,\gamma(L+1)) \in \Gamma_{p,q}$ 的选择取期望；每一层的神经元均匀随机选取：

$$\gamma(0) = p, \qquad \gamma(L+1) = q, \qquad \gamma(\ell) \sim \mathrm{Unif}(\{1,\ldots,n_\ell\}) \quad \text{独立同分布.}$$

最后，由于 1 的平均值是 1，按预期得到

$$\mathbb{E}\left[\left(\frac{\partial z_{q;\alpha}^{(L+1)}}{\partial x_{p;\alpha}}\right)^2\right] = \frac{2}{n_0}. \tag{124}$$

5.5.2 四阶矩计算

为简单起见，我们在网络输出上再施加一个 σ（这只会改变一个因子 2）。有

$$\mathbb{E}\left[\left(\frac{\partial\sigma(z_{q;\alpha}^{(L+1)})}{\partial x_{p;\alpha}}\right)^4\right] = \mathbb{E}\left[\sum_{\gamma_1,\ldots,\gamma_4\in\Gamma_{p,q}}\prod_{\ell=1}^{L+1} W_{\gamma_k}^{(\ell)}\xi_{\gamma_k;\alpha}^{(\ell)}\right]$$
$$= \sum_{\gamma_1,\ldots,\gamma_4\in\Gamma_{p,q}}\prod_{\ell=1}^{L+1}\mathbb{E}\left[\prod_{k=1}^{4} W_{\gamma_k}^{(\ell)}\right]\mathbb{E}\left[\prod_{k=1}^{4}\xi_{\gamma_k;\alpha}^{(\ell)}\right].$$

与二阶矩的情形一样，我们发现所有权重必须出现偶数次，于是记

$$\Gamma_{p,q}^{4,\text{even}} := \big\{\gamma_1,\dots,\gamma_4 \in \Gamma_{p,q} \,\big|\, \text{对所有}\ell,\ \text{多重集}\{W_{\gamma_k}^{(\ell)},\, k=1,\dots,4\} \\ \text{中的元素都具有偶重数}\big\}.$$

因此，

$$\begin{aligned}\mathbb{E}\left[\left(\frac{\partial\sigma(z_{q;\alpha}^{(L+1)})}{\partial x_{p;\alpha}}\right)^4\right] &= \mathbb{E}\left[\sum_{\gamma_1,\dots,\gamma_4\in\Gamma_{p,q}}\prod_{\ell=1}^{L+1} W_{\gamma_k}^{(\ell)}\xi_{\gamma_k;\alpha}^{(\ell)}\right] \\ &= \sum_{(\gamma_1,\dots,\gamma_4)\in\Gamma_{p,q}^{4,\text{even}}}\prod_{\ell=1}^{L+1}\mathbb{E}\left[\prod_{k=1}^4 W_{\gamma_k}^{(\ell)}\right]\mathbb{E}\left[\prod_{k=1}^4\xi_{\gamma_k;\alpha}^{(\ell)}\right].\end{aligned}$$

现在定义碰撞事件

$$C^{(\ell)} = C^{(\ell)}(\gamma_1,\dots,\gamma_4) := \{\gamma_1(\ell)=\cdots=\gamma_4(\ell)\}.$$

于是，

$$\mathbb{E}\left[\prod_{k=1}^4 W_{\gamma_k}^{(\ell)}\right]\mathbb{E}\left[\prod_{k=1}^4\xi_{\gamma_k;\alpha}^{(\ell)}\right] = \frac{1}{n_{\ell-1}^2}\left(1+\mathbf{1}_{C^{(\ell)}}+2\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}(\mu_4-1)\right)(1+\delta_{\ell 1}),$$

其中 $\mu_4=\int_{\mathbb{R}}x^4 d\mu(x)$，并且我们使用了 $\mathbf{1}_{C^{(\ell)}}\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}=\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}$。综合起来得到

$$\mathbb{E}\left[\left(\frac{\partial\sigma(z_{q;\alpha}^{(L+1)})}{\partial x_{p;\alpha}}\right)^4\right] = 2\left(\prod_{\ell=1}^{L+1}\frac{1}{n_{\ell-1}^2}\right)\sum_{(\gamma_1,\dots,\gamma_4)\in\Gamma_{p,q}^{4,\text{even}}}\prod_{\ell=1}^{L+1}\left(1+\mathbf{1}_{C^{(\ell)}}+2\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}(\mu_4-1)\right).$$

现在的技巧是：将求和变量从具有偶数次权重的四条路径改为两条路径。

习题。给定 $\gamma_1',\gamma_2'\in\Gamma_{p,q}$，证明恰有

$$6^{\#\text{碰撞}} = 6^{\sum_{\ell=1}^{L+1}\mathbf{1}_{C^{(\ell)}}}$$

组 $(\gamma_1,\dots,\gamma_4)\in\Gamma_{p,q}^{4,\text{even}}$ 给出相同的权重配置（但每个权重重复两次）。

因此得到

$$\begin{aligned}\mathbb{E}\left[\left(\frac{\partial\sigma(z_{q;\alpha}^{(L+1)})}{\partial x_{p;\alpha}}\right)^4\right] &= \frac{2}{n_0^2}\left(\prod_{\ell=1}^{L}\frac{1}{n_\ell^2}\right)\sum_{\gamma_1,\gamma_2\in\Gamma_{p,q}}\prod_{\ell=1}^{L+1}\left(1+5\mathbf{1}_{C^{(\ell)}}+6\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}(\mu_4-3)\right) \\ &= \frac{2}{n_0^2}\mathcal{E}\left[\prod_{\ell=1}^{L+1}\left(1+5\mathbf{1}_{C^{(\ell)}}+6\mathbf{1}_{C^{(\ell)}C^{(\ell-1)}}(\mu_4-3)\right)\right],\end{aligned}$$

其中期望 $\mathcal{E}$ 现在是对两条独立同分布路径 $\gamma_1,\gamma_2\in\Gamma_{p,q}$ 的选择取的，每层每个神经元均匀选取：

$$\gamma_k(\ell)\sim\text{Unif}(\{1,\dots,n_\ell\})\quad\text{独立同分布}.$$

最后我们做一点启发式分析：注意

$$\mathcal{P}[C^{(\ell)}]=\frac{1}{n_\ell},\qquad\qquad \mathcal{P}[C^{(\ell-1)},C^{(\ell)}]\approx\frac{1}{n_\ell n_{\ell-1}}=O(n^{-2}).$$

特别地，近似得到

$$\mathbb{E}\left[\left(\frac{\partial\sigma(z_{q;\alpha}^{(L+1)})}{\partial x_{p;\alpha}}\right)^4\right] \approx \frac{12}{n_0^2}\mathcal{E}\left[\prod_{\ell=1}^{L}\left(1+\frac{5}{n_\ell}+O(n^{-2})\right)\right] = \frac{12}{n_0}\exp\left[5\sum_{\ell=1}^{L}\frac{1}{n_\ell}+O\left(\frac{L}{n^2}\right)\right],$$

正如所需。

习题。将上一步计算中的推理精确化。

5.5.3 对 NTK 的类似计算

至此我们结束了对输入—输出 Jacobian（即网络输出关于输入的导数）的分析。几乎完全相同的分析可以转而用于研究参数—输出 Jacobian（即网络输出关于某个参数的导数），再对所有参数求和，就得到某个输入处的 NTK。类似于上面的计算，可以很快得到 NTK 的二阶与四阶矩。由此可得，输出关于每个参数的偏导数彼此独立（即其协方差为零），因此平均 NTK 比较简单，由其无限宽度值给出，而围绕该均值的涨落按 $e^\beta - 1$ 缩放。

5.6 开放问题与设想

我们已经表明，对于具有单个输入向量的随机 ReLU 网络，各种有意义的量可以直接计算。最后给出关于相关量的若干开放问题：

1. 初始化时的随机函数有多光滑？能否得到 Lipschitz 常数？它能否遭受对抗攻击？
2. 除了知道特征学习发生之外，能否清晰描绘特征学习的图景（即便只考虑一步）？这种特征学习与例如平均场网络 [23] 的特征学习，或 Yasaman 讲义中讨论的 NTK 大学习率区域，有何联系？
3. 我们能否对 ReLU 以外的激活函数有效地应用类似的路径计数论证？

译注：原文中的记号与推导疑点

以下是译本对原文的核查说明，并非作者讲义的一部分。

页码均指冻结英文 PDF 的实体页码，版本为 arXiv:2309.01592v3。

正文保留原文的公式与论断；这里区分可直接检验的代数问题、缺失的条件与尚待厘清的约定。这些说明不替代对原始研究文献中相应定理的审查。

1. **第 8 页，式 (34)：核递推的层指标**。原文将 K^l 表示为以第 l 层的三个核值为自变量的函数，而此前的递推及随后式 (35)–(37) 均从第 $l-1$ 层得到第 l 层；此处右端的层指标不一致。

2. **第 10 页，式 (43)：特征深度的倒数**。由前一式 $\epsilon^l = a\epsilon^{l-1} + O((\epsilon^{l-1})^2)$ 与指数衰减约定 $\epsilon^l \sim e^{-l/\xi_c}$，可知 $\xi_c^{-1} = -\log a$。原文却写 $\xi_c = -\log a$，与同页临界时 $\xi_c \to \infty$ 的叙述也不一致。

3. **第 12 页，式 (46)–(47)：两点函数归一化**。式 (46) 定义 $\mathbb{E}[z^l_{i_1} z^l_{i_2}] = \sigma_w^2 \delta_{i_1 i_2} G^l$，但式 (47) 又令 $G^l = n^{-1}\sum_j \mathbb{E}[z^l_j z^l_j]$。令 $i_1 = i_2$ 并对神经元平均，会得到 $G^l = \sigma_w^2 G^l$，对一般 σ_w^2 不成立，故两处定义含额外归一化因子。

4. **第 18 页，式 (77)：有限宽核的非对角分量**。链式法则中早期层参数贡献本应对 k, j 都求和；原文在该项前也乘了 δ_{kj}。对有限宽网络，这一非对角贡献一般不为零；输出指标因子化是在文中随后讨论的无限宽极限下成立，不能在此未经极限直接作为恒等式使用。

5. **第 19 页，式 (85)：损失归一化**。第 14 页定义经验损失为 $m^{-1}\sum_\alpha \ell_\alpha$，但式 (85) 将其关于函数值的导数直接写成残差，未保留 $1/m$。若采用未平均的损失或把 $1/m$ 吸收到时间变量中，这个表达式可以成立；原文未在这里明确转换约定。

6. **第 23 页，式 (102)：矩阵乘法与逆**。从 $\int_0^t e^{-t'\Theta_0} dt' = \Theta_0^{-1}(I - e^{-t\Theta_0})$ 得到的应是矩阵乘积的 (α, β) 元素，原文却逐元素相乘 $[\Theta_0^{-1}]_{\alpha\beta}(I - e^{-t\Theta_0})_{\alpha\beta}$，缺少中间指标的缩并。此外，写矩阵逆需要相应可逆性条件；奇异核可使用积分表达式，但不能不加说明直接使用逆。

7. **第 24 页，式 (104)：变常数公式的符号**。若残差满足 $\dot{R} = -(\Theta_0 + \Theta_t^{(1)})R$，则一阶修正为

$$R(t) = e^{-\Theta_0 t}\left[I - \int_0^t e^{+\Theta_0 t'}\Theta_{t'}^{(1)} e^{-\Theta_0 t'} dt'\right] R(0) + O(n^{-2}).$$

   原文积分中左边的指数也写作 $e^{-\Theta_0 t'}$；即使取可交换的标量常数修正，也不能得到正确的一阶解。

8. **第 25 页，式 (108)、(110)、(112)：平方损失与离散更新**。式 (108) 在平方损失的语境下写成 $\mathcal{L}_t = f_t/2$，缺少平方。从原文式 (109) 的两个参数更新直接展开，得到

$$\lambda_{t+1} - \lambda_t = \frac{\eta f_t^2}{n}(\eta\lambda_t - 4),$$

   而式 (110) 与 (112) 的前因子是 $\eta^2 f_t^2/n$。式 (112) 将 $1 - \eta\lambda_t + \eta^2 f_t^2/n$ 在初始时标为 ≥ 1，但在文中 $2 < \eta\lambda_0 < 4$、大 n 且初始 $f_0 = O(1)$ 时，这一因子通常小于 -1；增长的是其绝对值。正文均按原文保留。

9. **第 31 页：输入范数与卡方对数**。若只假设输入范数有界，而未取 $\|x_\alpha\| = 1$，则应有

$$\|Wx_\alpha\| \overset{d}{=} \|x_\alpha\|\sqrt{\chi^2_n/n}, \qquad\qquad X_{n,L+1} \overset{d}{=} \|x_\alpha\| \exp\left(\sum_{\ell=1}^{L+1} Y_\ell\right).$$

令 $Y = \frac{1}{2}\log(\chi^2_n/n)$，由 Gamma 分布的对数矩可得

$$\mathbb{E}[Y] = \frac{1}{2}\left[\psi(n/2) + \log 2 - \log n\right] = -\frac{1}{2n} + O(n^{-2}),$$
$$\mathrm{Var}(Y) = \frac{1}{4}\psi_1(n/2) = \frac{1}{2n} + O(n^{-2}),$$

其中 ψ 与 ψ_1 分别是 digamma 与 trigamma 函数。这与原文习题中的 $\mp 1/(4n)$ 系数不一致。原文随后说 Y_j 接近 1，但按其定义，Y_j 接近 0，e^{Y_j} 才接近 1；单个 Y_j 的标准差为 $O(n^{-1/2})$，其均值与方差才是 $O(n^{-1})$。因此原文关于 L/n 的直观解释不能逐字作为误差估计使用。

10. **第 32 页：神经元指标的条件**。四点函数等于 $\mathrm{Cov}((z_i^{(\ell)})^2, (z_j^{(\ell)})^2)$ 的习题须区分 $i \neq j$。若 $i = j$，则按同页公式右边为 $3\kappa_4^{(\ell)} + 2\mathbb{E}[(z_i^{(\ell)})^2]^2$，一般不等于 $\kappa_4^{(\ell)}$。

11. **第 33 页：微扰公式的层指标**。定理的期望与高斯积分均标为第 ℓ 层，修正系数却写作 $\kappa_4^{(\ell+1)}$。取 $\ell = 1$ 时第一层严格高斯，而第二层通常有非零四点函数，故此处存在层指标不一致。正文保留原式，不擅自决定应整体平移哪一组指标。

12. **第 34 页：高斯线性变换的条件**。原文 “Gaussian with 0 variance K” 与 $\mathcal{N}(0, K)$ 不一致。其后命题若允许 A 是与 W 独立的随机矩阵，则高斯分布公式应理解为给定 A 的条件分布。无条件分布一般是高斯混合，例如 $W \sim \mathcal{N}(0,1)$、A 独立地等概率取 1 或 2。原文未明确此条件。

13. **第 35–36 页：条件期望、积分维数与层指标**。引理证明在给定上一层的语境下，把条件二阶矩写成未标条件的期望；接下来的重期望内出现未定义指标 $z_{ij\alpha}^{(\ell+1)}$。第三步沿用 $\Sigma^{(\ell)}$ 却将左边写为第 ℓ 层，而前面的条件高斯公式对应第 $\ell+1$ 层；积分域又写成 $\mathbb{R}^{n_m}$，与 m 维 Fourier 变量不一致。第四步还将 κ_4 写成 k_4。这些符号均在原 PDF 中可见，译文按原样保留。

14. **第 37 页：中心化变量的高斯平均**。原文写 $0 = \mathbb{E}[X_i] = \langle X_i\rangle_G + O(n^{-2})$。但由第三步的一般微扰公式，非高斯分布与匹配方差的高斯分布之间通常有 $O(n^{-1})$ 的差异；对一般 σ，这里更强的 $O(n^{-2})$ 需要额外论证。例如取 $\sigma(t) = t^2$，则 $\langle X_i\rangle_G = C_W(3G^2 - \mathbb{E}[z_i^4]) = -3C_W\kappa_4$，通常为 $O(n^{-1})$。这不单独否定随后协方差递推的主导阶，但原文这一步不能直接照用。

15. **第 38 页：元论断的归一化与范围**。Jacobian 平方的对数正态表达式右边均值为 1，而第 41 页精确二阶矩为 $2/n_0$；必须说明是否省略了归一化。有限宽、零偏置 ReLU 网络还有全层灭活的正概率事件，从而 Jacobian 的平方可有零点原子，不能把该表达式读作有限宽下严格的对数正态分布。原文虽使用 $\simeq$，但未在此陈述具体极限、归一化或零点事件的处理。另外，本页 NTK 涨落的 $e^{5\beta}$ 与第 43 页的 $e^{\beta} - 1$ 使用同一个 β，其指数约定待核查。

16. **第 39 页：实际门控的独立性证明**。证明中的 “Conditional on ℓ” 未明确条件随机对象。在第一隐藏层全部预激活为负的事件上，所有后续预激活均为零；该事件在非零输入、独立对称连续权重下的概率为 $2^{-n_1} > 0$。因此实际门控不能在每层无条件地都是独立的 Bernoulli(1/2)。这指出证明概要缺少灭活事件的处理，不等于否定可通过辅助随机门控与符号对称性建立的输出依分布表示。

17. **第 40 页：路径与参数导数**。路径权重定义 $W^{(\ell)}_{\gamma(\ell-1)\gamma(\ell)}$ 与此前 $W^{(\ell)}_{ij}$ 中 i 为到达层、j 为出发层的约定相反。输出公式的外部因子写为 $W^{(\ell+1)}_{\gamma}$，但 ℓ 不在外部绑定；其后输入导数公式使用 $W^{(L+1)}_{\gamma}$。参数导数平方公式中的 x_{p_1,p_2} 未定义，路径约束将到达层指标再次写成 j，与前一公式的 i 不同，且 $(W^{(\ell)}_{ij})^2$ 的分母位于 k 的乘积之内，按字面会重复出现。末尾 NTK 对 W 求导，而前面习题对 $\widehat{W}$ 求导，两种参数化的比例因子须区分。

18. **第 41 页：二阶矩计算中的乘积**。原文把 $\mathbb{E}[\prod_{k=1}^{2}(W^{(\ell)}_{\gamma_k})^2]$ 写成两个权重的协方差公式，左边多出的平方使两边一般不等。随后路径计数又将 $\Gamma_{p,q}$ 写成 $\Gamma_{q,p}$；若输入输出宽度不同，这不仅是书写顺序的差异。门控的 1/2 必须在每个隐藏层各计一次。最终的 $2/n_0$ 与按正确两权重配对所作的二阶矩计数一致，但原文中间式有这些不一致。

19. **第 42–43 页：四阶矩与碰撞计数**。两处展开的第一行缺少对 $k = 1, \ldots, 4$ 的乘积。声称有 $6^{\#\text{碰撞}}$ 组四重路径的习题未说明重数或路径标记约定；若给定的两条路径完全相同，按通常的相同权重配置理解，四条路径只能全部相同，故只有一组，不能直接得到该计数。四阶矩公式还有可由最小网络检验的因子问题：取 $L = 1$、$n_0 = n_1 = n_2 = 1$、标准高斯 μ 和 $x > 0$，则两层权重的方差均为 2，在输出也施加 ReLU 后，

$$\mathbb{E}\left[\left(\partial_x \sigma(z^{(2)}(x))\right)^4\right] = \mathbb{E}[W_1^4 \mathbf{1}_{W_1>0}]\mathbb{E}[W_2^4 \mathbf{1}_{W_2>0}] = 6 \times 6 = 36,$$

    而第 43 页以 $2/n_0^2$ 开头的所谓精确路径期望式在该情形给出 $2(1+5)^2 = 72$。因此该式至少存在整体因子或边界门控约定的问题。末尾还把前一项的 $12/n_0^2$ 写成 $12/n_0$。这些是原文问题；译文未静默修改为推测的正确公式。

20. **第 43 页：不相关与独立**。原文将参数导数的 “independent” 解释为协方差为零；一般情况下，协方差为零只表示不相关，不足以推出独立。正文保留原文措辞并在此提示其逻辑强度不同。

参考文献

[1] R. M. Neal, *Priors for Infinite Networks*, pp. 29–53, Springer New York, New York, NY, ISBN 978-1-4612-0745-0, doi:10.1007/978-1-4612-0745-0_2 (1996).

[2] J. Lee, Y. Bahri, R. Novak, S. S. Schoenholz, J. Pennington and J. Sohl-Dickstein, *Deep neural networks as gaussian processes*, In *International Conference on Learning Representations* (2018).

[3] A. G. de G. Matthews, J. Hron, M. Rowland, R. E. Turner and Z. Ghahramani, *Gaussian process behaviour in wide deep neural networks*, In *International Conference on Learning Representations* (2018).

[4] Y. Cho and L. Saul, *Kernel methods for deep learning*, Advances in neural information processing systems **22** (2009).

[5] R. Novak, L. Xiao, J. Lee, Y. Bahri, G. Yang, J. Hron, D. Abolafia, J. Pennington and J. Sohl-Dickstein, *Bayesian deep convolutional networks with many channels are gaussian processes*, In *International Conference on Learning Representations* (2019).

[6] J. Hron, Y. Bahri, J. Sohl-Dickstein and R. Novak, *Infinite attention: NNGP and NTK for deep attention networks*, In *International Conference on Machine Learning*, pp. 4376–4386. PMLR (2020).

[7] L. Xiao, Y. Bahri, J. Sohl-Dickstein, S. Schoenholz and J. Pennington, *Dynamical isometry and a mean field theory of CNNs: How to train 10,000-layer vanilla convolutional neural networks*, In J. Dy and A. Krause, eds., *Proceedings of the 35th International Conference on Machine Learning*, vol. 80 of *Proceedings of Machine Learning Research*, pp. 5393–5402. PMLR (2018).

[8] C. K. Williams and C. E. Rasmussen, *Gaussian processes for machine learning*, vol. 2, MIT press Cambridge, MA (2006).

[9] S. S. Schoenholz, J. Gilmer, S. Ganguli and J. Sohl-Dickstein, *Deep information propagation*, In *International Conference on Learning Representations* (2017).

[10] D. A. Roberts, S. Yaida and B. Hanin, *The principles of deep learning theory*, Cambridge University Press Cambridge, MA, USA (2022).

[11] L. Xiao, J. Pennington and S. Schoenholz, *Disentangling trainability and generalization in deep neural networks*, In *International Conference on Machine Learning*, pp. 10462–10472. PMLR (2020).

[12] Y. Bahri, J. Kadmon, J. Pennington, S. S. Schoenholz, J. Sohl-Dickstein and S. Ganguli, *Statistical mechanics of deep learning*, Annual Review of Condensed Matter Physics **11**, 501 (2020).

[13] A. Jacot, F. Gabriel and C. Hongler, *Neural tangent kernel: Convergence and generalization in neural networks*, In *Proceedings of the 32nd International Conference on Neural Information Processing Systems*, NIPS'18, p. 8580–8589. Curran Associates Inc., Red Hook, NY, USA (2018).

[14] J. Lee, L. Xiao, S. Schoenholz, Y. Bahri, R. Novak, J. Sohl-Dickstein and J. Pennington, *Wide neural networks of any depth evolve as linear models under gradient descent*, Advances in neural information processing systems **32** (2019).

[15] E. Dyer and G. Gur-Ari, *Asymptotics of wide networks from feynman diagrams*, In *International Conference on Learning Representations* (2020).

[16] J. Huang and H.-T. Yau, *Dynamics of deep neural networks and neural tangent hierarchy*, In H. D. III and A. Singh, eds., *Proceedings of the 37th International Conference on Machine Learning*, vol. 119 of *Proceedings of Machine Learning Research*, pp. 4542–4551. PMLR (2020).

[17] A. Lewkowycz, Y. Bahri, E. Dyer, J. Sohl-Dickstein and G. Gur-Ari, *The large learning rate phase of deep learning: the catapult mechanism*, arXiv preprint arXiv:2003.02218 (2020).

[18] S. Yaida, *Non-gaussian processes and neural networks at finite widths*, arXiv preprint arXiv:1910.00019 (2019).

[19] B. Hanin, *Correlation functions in random fully connected neural networks at finite width*, arXiv preprint arXiv:2204.01058 (2021).

[20] B. Hanin, *Which neural net architectures give rise to exploding and vanishing gradients?*, In *Advances in Neural Information Processing Systems* (2018).

[21] B. Hanin and M. Nica, *Products of many large random matrices and gradients in deep neural networks*, Communications in Mathematical Physics (in Press). arXiv:1812.05994 (2019).

[22] B. Hanin and M. Nica, *Finite depth and width corrections to the neural tangent kernel*, ICLR 2020 and arXiv:1909.05989 (2019).

[23] S. Mei, A. Montanari and P.-M. Nguyen, *A mean field view of the landscape of two-layer neural networks*, Proceedings of the National Academy of Sciences **115**(33), E7665 (2018).