
量子科学中的机器学习现代应用

*Modern Applications of Machine
Learning in Quantum Sciences*

Anna Dawid et al.

arXiv:2204.04198v4 · arXiv · 2025

Model: OpenAI Codex (GPT-5)

审核: 曹溪能

Updated: 30 Aug 2026

原著信息

Anna Dawid^{1,2,3*}, Julian Arnold^{4†}, Borja Requena^{2†}, Alexander Gresch^{5,6†}, Marcin Płodzień², Kaelan Donatella⁷, Kim A. Nicoli^{8,9}, Paolo Stornati², Rouven Koch¹⁰, Miriam Büttner¹¹, Robert Okuła^{12,13}, Gorka Muñoz-Gil¹⁴, Rodrigo A. Vargas-Hernández^{15,16,17}, Alba Cervera-Lierta¹⁸, Juan Carrasquilla¹⁶, Vedran Dunjko¹⁹, Marylou Gabrié²⁰, Patrick Huembeli^{21,22}, Evert van Nieuwenburg^{19,23}, Filippo Vicentini^{21,24}, Lei Wang^{25,26}, Sebastian J. Wetzel²⁷, Giuseppe Carleo²¹, Eliška Greplová²⁸, Roman Krems²⁹, Florian Marquardt^{30,31}, Michał Tomza¹, Maciej Lewenstein^{2,32}, Alexandre Dauphin^{2,33*}.

1. 波兰华沙大学物理学院.
2. 西班牙巴塞罗那科学技术研究院光子科学研究所 (ICFO), Castelldefels 08860.
3. 美国纽约 Flatiron Institute 计算量子物理中心.
4. 瑞士巴塞尔大学物理系.
5. 德国杜塞尔多夫 Heinrich Heine 大学理论物理研究所.
6. 德国汉堡工业大学量子启发与量子优化研究所.
7. 法国巴黎大学、法国国家科学研究中心 (CNRS) 材料与量子现象实验室.
8. 德国柏林工业大学机器学习组.
9. 德国柏林学习与数据基础研究所 (BIFOLD), 10587 Berlin.
10. 芬兰 Aalto 大学应用物理系, Espoo.
11. 德国 Freiburg 大学物理研究所.
12. 波兰 Gdańsk 大学国际量子技术理论中心.
13. 波兰 Gdańsk 工业大学电子、电信与信息学院、电子、电信与信息学院算法和系统建模系.
14. 奥地利 Innsbruck 大学理论物理研究所.
15. 加拿大 Toronto 大学化学系.
16. 加拿大 Toronto Vector Institute for Artificial Intelligence, MaRS Centre.
17. 加拿大 Hamilton McMaster 大学化学与化学生物学系.
18. 西班牙 Barcelona Supercomputing Center.
19. 荷兰 Leiden 大学 LIACS.
20. 法国 École Polytechnique 应用数学中心 (CMAP).
21. 瑞士 École Polytechnique Fédérale de Lausanne (EPFL) 物理研究所.
22. 美国加利福尼亚州 Palo Alto, Menten AI, Inc.
23. 丹麦 Copenhagen Niels Bohr Institute.
24. 法国 Palaiseau, CNRS, École Polytechnique 与 Institut Polytechnique de Paris 的 CPHT, F-91128.
25. 中国科学院凝聚态物理国家重点实验室与物理研究所, 北京.
26. 中国松山湖材料实验室, 东莞.
27. 加拿大 Waterloo Perimeter Institute for Theoretical Physics.
28. 荷兰 Delft University of Technology Kavli Institute of Nanoscience, NL-2600 GA Delft.
29. 加拿大 Vancouver University of British Columbia 化学系.
30. 德国 Erlangen Max Planck Institute for the Science of Light.
31. 德国 Erlangen-Nürnberg Friedrich-Alexander University 物理系.
32. 西班牙 Barcelona, ICREA, Pg. Lluís Companys 23, 08010.
33. 法国 Massy, PASQAL SAS, 7 Rue Leonard de Vinci, 91300.

† 这些作者贡献相同.

★ 通讯邮箱: a.m.dawid@leidenuniv.nl, Alexandre.Dauphin@pasqal.com.

原文版本日期: 2025 年 9 月 21 日; arXiv:2204.04198v4 (quant-ph, 2025 年 6 月 7 日)

译本说明

本译本以 arXiv:2204.04198v4 的 287 页 PDF 为可见内容与结构的最高依据，并以同版本官方 TeX 源文件辅助恢复公式、标签、引用键和原始图件。当辅助源与 PDF 冲突时，以 PDF 为准；疑似源文错误记录在项目的 ‘issues.md’ 中，不作静默修改。

排版基本流程如下：

1. 按可审查的章节或小节单元翻译，并逐单元与源 PDF 核对；
2. 保留公式、定义、图表、算法、引用、标签和编号关系；
3. 分别进行中文与术语、数学与结构、编译与视觉三轮审校。

排版遵循本项目保存的 MathTranslations 个性化模板基线；术语、问题、构建与审校证据分别见随项目交付的维护文件。

审核：曹溪能
30 Aug 2026

目录

原著信息	i
译本说明	ii
献词	1
前言	2
第 1 章 引言	4
1.1 计算机如何学习?	4
1.2 学习机器的历史回顾	5
1.3 统计物理视角下的学习机器	7
1.4 任务示例	8
1.5 学习类型	10
1.6 如何阅读本书	11
第 2 章 机器学习基础	15
2.1 作为优化问题的学习	15
2.2 泛化与正则化	19
2.3 机器学习的概率观点	22
2.4 机器学习模型	25
2.4.1 线性 (岭) 回归	26
2.4.2 逻辑回归	28
2.4.3 支持向量机	29
2.4.4 神经网络	31
2.4.5 自动编码器	33
2.4.6 自回归神经网络	34
2.5 反向传播	36
第 3 章 相分类	42
3.1 研究物质相的原型物理系统	42
3.1.1 Ising 模型	42
3.1.2 Ising 规范理论	44
3.2 无神经网络的无监督相分类	45
3.2.1 主成分分析	46
3.2.2 t 分布随机邻域嵌入	48
3.3 利用神经网络进行监督相分类	49
3.4 利用神经网络进行无监督相分类	50
3.4.1 利用自编码器学习	51
3.4.2 混淆学习	52
3.4.3 基于预测的方法	53
3.5 机器学习模型的可解释性	55

3.5.1	解释模型参数的困难	56
3.5.2	通过瓶颈实现可解释性	56
3.5.3	基于 Hessian 的可解释性	61
3.5.4	相分类的概率视角	63
3.6	展望与开放问题	64
第 4 章	高斯过程与其他核方法	65
4.1	核技巧	65
4.1.1	核技巧背后的直观认识	66
4.1.2	作为 Hilbert 空间的函数空间	67
4.1.3	再生核 Hilbert 空间	68
4.1.4	表示定理	70
4.1.5	核技巧的推论	70
4.2	核方法	71
4.2.1	核岭回归	72
4.2.2	支持向量机	73
4.2.3	高斯过程	77
4.2.4	训练高斯过程	81
4.3	贝叶斯优化	82
4.4	选择合适的模型	84
4.4.1	贝叶斯信息准则	86
4.4.2	核搜索	86
4.5	量子科学中的应用	87
4.5.1	逆问题	88
4.5.2	改进量子动力学、物理模型与实验	90
4.5.3	外推问题	91
4.5.4	变分量子算法的贝叶斯优化	92
4.6	展望与开放问题	93
第 5 章	神经网络量子态	94
5.1	变分方法	95
5.1.1	具有精确期望值的变分态	95
5.1.2	具有近似期望值的变分态	96
5.2	表示波函数	99
5.2.1	受限 Boltzmann 机	100
5.2.2	自回归与循环神经网络	101
5.2.3	容量与纠缠	102
5.2.4	实现对称性	105
5.2.5	局限性	106
5.3	应用	107
5.3.1	寻找基态	107
5.3.2	实时演化	108

5.3.3	虚时演化	110
5.3.4	费米子体系	111
5.3.5	量子电路的经典模拟	114
5.3.6	开放量子系统	116
5.3.7	量子态层析	117
5.4	展望与开放问题	120
第 6 章	强化学习	122
6.1	强化学习基础	123
6.1.1	延迟奖励	124
6.1.2	探索与利用	125
6.1.3	Markov 决策过程	126
6.1.4	无模型强化学习与基于模型的强化学习	127
6.1.5	价值函数与 Bellman 方程	128
6.2	基于价值的方法	130
6.2.1	Q-learning	131
6.2.2	Double Q-learning	132
6.2.3	用神经网络实现 Q-learning	133
6.3	策略梯度方法	134
6.3.1	REINFORCE	135
6.3.2	用神经网络实现 REINFORCE	138
6.4	演员-评论家方法	139
6.5	投影模拟	141
6.6	示例与应用	144
6.6.1	玩具示例	144
6.6.2	围棋和 Atari 游戏	146
6.6.3	量子反馈控制	147
6.6.4	量子电路优化	148
6.6.5	量子纠错	149
6.6.6	量子实验设计	152
6.6.7	构建最优松弛	153
6.7	展望与开放问题	155
第 7 章	量子科学中的深度学习专题	156
7.1	可微编程	156
7.1.1	自动微分	158
7.1.2	量子物理问题中的应用	163
7.2	多体物理中的生成模型	165
7.2.1	使用或不使用数据训练	166
7.2.2	深度生成模型的分类	167
7.2.3	一个重要示例：归一化流	169
7.3	用于实验的机器学习	174

7.3.1	实验装置自动化	174
7.3.2	飞行时间图像的机器学习分析	179
7.3.3	Hamiltonian 学习	181
7.3.4	实验的自动化设计	183
第 8 章	用于深度学习的物理学	187
8.1	机器学习的统计物理学	187
8.1.1	感知机的容量	188
8.1.2	教师-学生范式: 研究泛化的玩具模型	192
8.1.3	数据结构模型	197
8.1.4	学习动力学	199
8.2	量子机器学习	201
8.2.1	基于门的量子计算	201
8.2.2	什么是量子机器学习?	203
8.2.3	理想量子计算机	203
8.2.4	含噪中等规模量子时代	204
8.2.5	带量子核的支持向量机	206
8.2.6	变分方法	207
8.2.7	用于量子机器学习的参数化量子电路	210
8.2.8	当前的实验与理论局限	211
第 9 章	结论与展望	214
	致谢	217
附录 A	主成分分析的数学细节	219
附录 B	核技巧的推导	221
附录 C	将核矩阵选作高斯过程的协方差矩阵	224
	参考文献	226
	图清单	288
	算法清单	290
	缩略语清单	291
	主题索引	291
	术语索引	296

献词

谨以此书纪念 Peter Wittek.

前言

我们生活在一个令人着迷的时代，科学家开始把人工智能（artificial intelligence, AI）算法用于发现知识。这个蓬勃发展的领域不断取得进展，科学界对这些方法的兴趣与信心因而迅速增长。图 0.1 展示了物理学、化学和材料科学中基于机器学习（machine learning, ML）的论文所占比例，由此可以看出这一趋势。随着机器学习应用日益增多，跟踪所有进展变得颇具挑战。此外，机器学习领域发展迅速，而有意把机器学习工具纳入自身研究的科学家又需要跨越与该领域之间的鸿沟；能够有效帮助他们完成这一过渡、且可靠的中级学习材料并不容易找到。

创作本书的想法源于 2021 年 8 月 23 日至 9 月 3 日在波兰华沙举办的量子物理与化学中的机器学习暑期学校。因此，本书旨在以教学性和自洽的方式综述机器学习在量子科学中的现代应用。本书的科学内容受到该暑期学校讲师与特邀报告人所讲授主题的启发。我们邀请读者参阅文献 [2] 中的暑期学校教程，也欢迎重复使用为本书制作并收录于文献 [3] 中的图片。

本书面向希望熟悉机器学习方法的量子科学研究者。因此，我们假定读者具备线性代数、概率论和量子信息论的基础知识，也熟悉拉格朗日乘子、希尔伯特空间和蒙特卡罗方法等概念。我们还假定读者熟悉量子力学，并对量子科学当前面临的挑战有基本认识。

本书大致分为三个部分。第一部分致力于打下坚实的机器学习概念基础，以便理解机器学习在自然科学中的应用。第二部分深入探讨机器学习在量子科学中的四个核心应用领域，其中包括在监督学习、无监督学习和强化学习算法中使用深度学习与核方法，以解决相分类、多体量子态表示、量子反馈控制和量子线路优化等问题。第三部分介绍并讨论更为专门的主题，例如可微编程、生成模型、研究机器学习的统计物理方法以及量子机器学习。总而言之，本书讨论了人工智能与量子科学之间富有成效的相互作用，图 0.2 给出了示意表示。




图 0.1: 物理学、材料科学和化学中基于机器学习的论文数量正呈指数增长。改编自文献 [1]。




图 0.2: 人工智能与量子科学之间的相互作用, 尤其是与量子计算、多体物理和量子化学之间的相互作用. 本书不仅关注人工智能对量子科学的影响, 还讨论统计物理和量子计算反过来对机器学习产生的影响.

我们的目标并不是穷举机器学习在量子科学中的应用, 也不是写成该领域的一部完整综述. 已有综述很好地概括了最新成果 [4, 5, 6]. 相反, 我们希望为读者提供足够的知识、直觉和实践诀窍, 使他们能够开始在自己的研究中实现所选择的机器学习方法. 为此, 我们在保持领域概览足够宽广的同时, 选取了我们认为具有教学吸引力的机器学习应用. 我们关注的不只是已经完成了什么, 还关注读者能够做什么. 为实现这一目标, 每章末尾都会给出我们认为重要且前景可期的展望与开放问题.

引言

制造智能机器，即能够学习，并能在思考和推理中运用所积累知识的机器，是人类文明长久以来的梦想。我们对人脑、智能和心理了解得越多，这项事业似乎就越富挑战。然而，尽管创造人工智能面临众多障碍与挑战，自然科学、认知科学、数学和计算机科学研究者的共同努力已经造就了令人瞩目的机器系统，它们正在变革我们的日常生活、工业和科学。

1.1 计算机如何学习？

人工智能的终极目标，是赋予机器形成概念与进行抽象的能力。对人类而言，这两种能力正是学习知识表示并依据经验推理的基础机制。同一个观念可以有多种表示方式。例如，一段音乐可以用数字格式编码在计算机中，可以用模拟格式刻录在黑胶唱片上，也可以写成乐谱。尽管这些表示截然不同，音乐作品本身却是同一首。因此，抽象观念的性质不依赖于数据来源。

概念化与抽象还使我们能够在某一种表示内部考察不同的细节层次，或在保留相关信息的同时从一个层次切换到另一个层次 [7, 8, 9, 10, 11]。人脑尤其擅长从知识的不同表示中提取抽象观念。在日常生活中，我们不断处理来自多个来源的信息；这些信息可能以完全不同的方式表示同一个概念。例如，我们可以通过看见一条狗、听见或闻到它、读到“狗”这个词、在某人脸上画一个狗鼻子，甚至用双手投出形似狗的影子，来辨认“狗”这一概念。这种抽象与概念化水平使我们能够连接高层观念并进行推理。上述人脑性质共同构成了我们所谓的智能。若能把这些性质赋予计算机，就会得到一种通用的问题求解机器。

当今技术发展到了这样一个阶段：人脑与计算机各自天然擅长的任务集合彼此并不相同。¹ 有些任务对计算机容易、对人类困难，这些问题可以用一组形式化数学规则描述。因而，计算机擅长求解逻辑、代数、几何和优化问题；我们可以用硬编码方案或基于知识的人工智能处理它们。可是，我们还希望处理难以用形式化数学方式表述的问题，例如人脸识别；也希望处理尚不知确切数学表述的问题，例如探测新的量子相。

一个格外令人振奋的方向，是开发并非由人显式编程的算法。核心原则是让计算机从经验（或数据）中学习。向这种数据驱动范式的转变催生了机器学习，图 1.1 给出了示意图。机器学习运用应用统计学的基本概念，强调借助计算机估计复杂函数，而较少强调证明这些函数估计的置信区间 [13]。随着深度学习（deep learning, DL）兴起，这一趋势进一步加速：规模庞大、参数高度丰富的层级模型能够以前所未有的精度处理现

¹这一观察最早出现于 20 世纪 80 年代，被称为莫拉维克悖论。Moravec 在 1988 年写道 [12]：“让计算机在智力测试或西洋跳棋中表现出成年人的水平相对容易；要让它们在感知和运动方面拥有一岁儿童的技能，却很难甚至不可能。”




图 1.1: 基于算法的传统编程与基于经验或数据驱动方法之间差异的示意图；后者是机器学习范式的支柱。机器学习通过从数据中提取共同特征，使计算机朝着学习抽象迈出第一步。

实数据中的复杂模式。有趣的是，许多深度学习架构被设计为模仿人类思维过程的某些性质，例如理解视觉模式中的相关性或声音信号中的递归性。图 1.2 示意了人工智能、机器学习与深度学习三者之间的关系。

要让计算机学习，需要三项主要要素：

1. 一个有待解决的任务（第 1.4 节）；
2. 可以视为经验之等价物的数据。数据例如可以由一个可交互环境提供，并使任务得以解决（第 1.5 节）；
3. 一个学习如何解决任务的模型（第 2.4 节）。

为了检查计算机是否成功学会解决任务，我们需要定义性能度量；它可以简单到只比较模型预测与预期答案。依照这些概念，学习过程可以描述为：在给定任务与数据上，反复降低模型误差或提高模型性能。

1.2 学习机器的历史回顾

学习理论的基础早在 20 世纪 40 年代就已奠定。它沿着两条平行路径发展：一条是基于知识的方法，几十年来一直主导人工智能研究；另一条是如今方兴未艾的基于数据的方法。多年来，机器学习曾使用控制论、联结主义等不同名称，也经历过几轮周期：先是极度流行，²继而遭受批评、引发失望和经费削减，若干年乃至几十年后又重获关注 [13]。为使读者了解我们所承继的先驱工作，下面依据文献 [13, 15, 16, 17] 简述机器学习发展的若干里程碑：

- 1943 年——Walter Pitts 与 Warren McCulloch 创立一种受人脑神经网络启发、称为阈值逻辑（threshold logic）的计算机模型。他们的研究领域称为控制论（cybernetics）。

²有人认为，除非我们重新思考人工智能，或将其与基于知识的方法相结合，否则“人工智能寒冬”即将来临 [14]。同样需要记住，新兴技术经常经历这种炒作周期。




图 1.2: 人工智能、机器学习和深度学习之间关系的示意图, 并列出各领域的例子, 包括支持向量机 (SVM)、主成分分析 (PCA)、神经网络 (NN) 和卷积神经网络 (CNN)。

- 1949 年——Donald Hebb 提出关于生物系统如何学习的假说, 并建立赫布学习 (Hebbian learning)。例如, 某些神经元若“一起激发, 就会连接在一起”。
- 1957 年——Frank Rosenblatt 提出模拟单个神经元的 Rosenblatt 感知机 (Rosenblatt perceptron)。感知机也称“人工神经元”; Marvin Minsky 和 Seymour Papert 在 1969 年加以修改后, 它直到今天仍广泛用作人工神经网络的基本构件。
- 1962 年——David Hubel 与 Torsten Wiesel 首次给出用微电极记录到的单个生物神经元的响应性质。
- 1969 年——Marvin Minsky 与 Seymour Papert 指出包括单个人工神经元在内的线性模型在计算上的限制与缺点, 促成第一次“人工智能寒冬”。
- 1986 年——David Rumelhart、Geoffrey Hinton 与 Ronald Williams 用反向传播 (backpropagation) 训练含一两个隐藏层的神经网络。加之 Hebb 思想复兴, 这使当时称为联结主义 (connectionism) 的领域重获关注。同年, David Rumelhart、James McClelland 等出版广受讨论的两卷本著作 *Parallel Distributed Processing*, 讨论已有成果并汇集该领域的原创贡献, 其中包括反向传播与玻尔兹曼机。
- 20 世纪 90 年代中期——出现第二次人工智能寒冬。文献 [13] 将其归因于研究共同体过分雄心勃勃的宣称导致投资者失望, 同时只需较少计算资源的核方法取得进展。

人工智能的发展与神经科学如此紧密交织, 颇耐人寻味。这是合理的, 因为人脑以实例证明了智能行为是可能的。一种自然的人工智能路线, 是尝试逆向工程人脑以再现其功能。然而, 尽管感知机受到生物神经元启发, 一些机器学习模型也松散地借鉴了神

经科学发现，如今的共识却是：模型不应被设计成生物功能的逼真模拟器 [13].³ 相反，科学家正尝试用机器学习破解人脑之谜。

自 2006 年起，利用反向传播高效训练深层神经网络取得突破 [18]，随后多项分析确认了深度的重要性，深度学习因而再度蓬勃发展。与此同时，近几十年计算能力迅速提高，使研究更大的机器学习模型成为可能。图形处理器（GPU）的发展在这里尤其重要 [19, 20]：神经网络等基于矩阵和向量运算、可高度并行化的算法能充分利用 GPU 的并行架构，比中央处理器（CPU）更有效地处理海量数据。此外，世界各地开始产生并存储大量易于获取的电子数据 [21, 22, 23]，从而为数据驱动编程提供条件。

此后的进展使某些此前只见于科幻作品的概念成为现实，例如自动驾驶汽车，以及能在人工面孔上模仿人类情绪的机器人——尽管我们距离类人智能依然遥远 [24]。深度学习多年来一直主导计算机视觉，并在时间序列分析中取得巨大成功，包括股票市场和天气预报等应用 [25]。另一条富有成果的路线是自然语言处理；其中，序列到序列模型取得了显著成就，甚至能够结合文本和图像 [26, 27]。基于深度学习的算法还在电子游戏 [28, 29] 以及围棋等复杂棋类游戏 [30] 中达到了超越人类的水平。

总体而言，计算能力持续提高、机器学习易于应用到现实问题，共同支撑着该领域不断进步。社会产生的数据日益增多，处理这些数据又能带来经济收益，因而最大的科技公司投入巨额资源开发机器学习模型。该领域最重要的一些研究团队与这些公司有关，并非偶然。重要的是，我们应当理解这个领域的趋势在多大程度上由科学发现的渴望推动，又在多大程度上由某一家科技巨头的特定需求塑造。总之，机器学习已经成为日常工具，隐身于我们今天使用的多种技术之中 [24]；它有潜力解决现代世界的一些重大问题，从而改善世界各地人们的生活质量。

1.3 统计物理视角下的学习机器

还值得指出的是，上述与机器学习和神经网络有关的人工智能、数据科学、认知科学及神经科学进展，也与自旋玻璃和神经网络统计物理的发展交织在一起。已故 Naftali Tishby 的讲座[统计物理与机器学习：三十年回顾](#)对此作了精彩回顾。下面仿照第 1.2 节列出历史里程碑，但侧重统计物理成果：

- 1975 年——Philipp W. Anderson 与 Samuel F. Edwards 建立 Edwards–Anderson 自旋玻璃模型，其中 Ising 自旋之间具有短程随机相互作用。
- 1975 年稍后——David Sherrington 与 Scott Kirkpatrick 建立具有无限程相互作用的 Sherrington–Kirkpatrick 自旋玻璃模型；其平均场解理应精确。他们提出用副本技巧求解，但这一近似解在低温下明显不正确。
- 1979 年——Giorgio Parisi 提出 Sherrington–Kirkpatrick 模型精妙的副本对称性破缺解。
- 1982 年——John J. Hopfield 发表关于吸引子神经网络的奠基论文。他假设神经

³有趣的是，我们知道真实生物神经元计算的函数与现代神经网络中的感知机很不相同，但迄今提高生物真实性并未改善模型性能 [13]。

元间耦合对称，从而把模型联系到由 N 个自旋构成、与自旋玻璃非常相似的无序 Ising 模型，并得到最大存储容量 $0.14N$ 。

- 1985 年——Daniel Amit、Hanoach Gutfreund 与 Haim Sompolinsky 建立 Hopfield 模型的统计物理，并把有限存储容量联系到自旋玻璃相变。
- 1987 年——Marc Mézard、Giorgio Parisi 与 Miguel Ángel Virasoro 出版 *Spin Glass Theory and Beyond: An Introduction to the Replica Method and Its Applications*. 这是较早把统计物理与神经网络结合起来的著作之一，也把它们置于优化和蛋白质折叠等复杂系统的更广泛背景中。
- 1988 年——Elizabeth Gardner 建立所谓面向机器学习的 Gardner 纲领，其中学习能力与能完成学习任务和师生情景的神经网络在参数空间中所占相对体积相联系（见第 8.1.1 节）。
- 1989 年——Daniel Amit 出版 *Modeling Brain Function: The World of Attractor Neural Networks*，通过引入以时间序列编码信息的动力学模式，拉近神经生理学与人工神经网络的距离。
- 1990 年——Géza Györgyi 利用感知机的 Gardner 纲领表明，学习过程中可以出现从不良泛化到良好泛化的尖锐相变。
- 1995 年——David Saad、Sara Solla、Michael Biehl 与 Holm Schwarze 调整 Gardner 的思想，用来研究感知机以及称为委员会机的简单双层神经网络中的梯度下降动力学。
- 2010 年代后期——Nicolas Macris、Jean Barbier、Lenka Zdeborová 与 Florent Krzakala 开始为感知机和委员会机的统计力学预测给出严格数学证明。
- 2010 年代至今——深度学习爆发后，人们重新燃起对学习之统计力学方法的兴趣。针对愈加复杂模型的分析不断发展，开始弥合感知机与深层神经网络之间的距离。
- 2021 年——Giorgio Parisi 因“发现从原子到行星尺度物理系统中无序与涨落之间的相互作用”获得诺贝尔物理学奖。
- 2024 年——John J. Hopfield 与 Geoffrey Hinton 因“使利用人工神经网络进行机器学习成为可能的基础性发现与发明”获得诺贝尔物理学奖。

第 8.1 节将更详细地讨论统计物理与机器学习的交汇。

1.4 任务示例

如前所述，让计算机学习所需的第一项要素是学习任务（learning task）这一概念。典型机器学习任务研究受解释变量 x 影响的响应变量 $y(x)$ 。原则上， y 或 x ，或者两者同时为连续、离散乃至类别变量，都不受限制。⁴ 本书将两种变量都限制为定量变量，必

⁴例如，自然语言处理中的输入是句子中的词，我们仍可通过合适的连续或离散编码表示这些词并加以处理。

要时先作相应编码. 这样就可以直接从数值角度处理变量, 并容易地按需求调整.

首先考虑回归 (regression) 任务. 通常假定变量 x 与 y 之间存在直接且往往确定性的关系. 更确切地说, 我们试图用变量 x (输入) 表示变量 y (输出或目标). 记号表明, 两者一般都可以是多维的. 回归的目标是找到函数 f , 使所有可能的 (x, y) 元组都满足映射 $y = f(x)$. 实际上, 我们既不能在所有可能函数组成的集合上优化, 也不能遍历 x 的整个定义域. 因此, 我们转而使用有限数据集, 寻找一个把每个输入 x 映射到对应目标 y 的模型. 模型通常预先给定到若干参数为止,⁵再调节参数以拟合数据集. 最简单的模型假定输入与输出呈线性关系; 第 2.4.1 节将详述这一原型. 在此基础上, 可以通过让模型参数及输入 x 以非线性方式出现而作出多种扩展. 社会学 (如年薪随工作年限的变化)、心理学 (如感知幸福程度与财富的关系)、金融学 (如房价对社会经济因素的依赖), 当然还有 (量子) 物理与化学, 都包含有趣的回归问题. 本书的例子包括第 4.5 节中量子化学势能面的预测, 以及第 7.3 节中根据测量数据估计 Hamiltonian 参数.

另一大类任务是分类 (classification). 这里的目标是用算法给样本赋予离散类别标签. 与回归不同, 我们优化模型以寻找从输入向量 x 到目标 y 的映射, 后者编码各个可能类别的表示. 最简单的是二分类, 算法必须区分两个类别, 例如真与假. 涉及两个以上类别时, 称为多类分类. 一个经典例子, 是把著名的 MNIST 数据集 [31] (名称源自 Modified National Institute of Standards and Technology) 中的手写数字图像分到十个类别, 每类对应 0 到 9 中的一个数字. 其他著名机器学习分类数据集包括 Iris [32]、CIFAR-10 和 CIFAR-100 [33] 以及 ImageNet [34].⁶ 物理学中的常见例子是区分不同的经典与量子物态, 见第 3 节; 第 7.3 节介绍的 (量子) 实验自动化, 也使用了分类子程序.

回归和分类任务都需要训练数据集, 其中每个输入 x 样本都配有相应标签 y . 不过, 也有不需要显式标签的任务. 例如密度估计 (density estimation) 旨在推断数据集的概率密度函数. 它与生成问题 (generative problem) 直接相关, 后者的目标是生成与给定输入数据相似的新数据实例. 两者的区别在于: 生成问题不要求显式知道或重建底层数据分布, 也能采样新实例. 第 7.2 节将详述密度估计.

上述情形都试图推断某个预先给定数据集的性质. 另有一些任务从零开始, 即时构建数据集, 再从中学习. 学习玩游戏就是典型例子: 我们从一张白纸开始, 在游戏过程中根据获得的经验逐步建立数据集, 并从这些数据中 (或在收集数据的同时) 学习一个函数, 使它能根据当前游戏状态选择尽可能好的行动或走法. 收集经验与学习可以周期性交替, 也可以同时进行.

这份任务清单当然并不穷尽. 其他不能直接归入上述类别的例子包括文本翻译、缺失值插补、异常检测与数据去噪等.

⁵也存在非参数方法, 例如见第 7.2.2 节和第 4.4.2 节.

⁶Iris 数据库含 150 个数据点, 描述三种鸢尾花, 每点有四个特征. CIFAR-10 数据集含 60,000 幅 32×32 彩色图像, 分属 10 类, 其名称源自 Canadian Institute for Advanced Research. ImageNet 则是一个拥有逾一千万幅带标签图像的庞大项目, 最常用子集涵盖 1,000 个物体类别.

1.5 学习类型

学习的第二项要素是数据 (data)；数据是否可获取，往往也决定了必须考虑哪种学习类型。上一节所述任务概念与数据显然彼此交织：某些任务只有数据充分时才能解决；反过来，更丰富的数据集又使人看似只需很小代价就能从一个任务迁移到另一个任务。“数据”一词在不同领域可指多种概念，但机器学习共同体对它有精确定义。通常，数据指数据集 $\mathcal{D}$ ，其中包含有限多个数据实例，常称为数据点 $\mathbf{x}_i$ 。数据点可以直接组成 $\mathcal{D} = \{\mathbf{x}_i\}$ ，也可以配有预定义标签或目标 $\mathbf{y}_i$ ，即 $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}$ 。为简化记号，还可以把输入数据点集合 $\{\mathbf{x}_i\}$ 表成矩阵 $\mathbf{X}$ ，按行或按列堆叠均可。

记号虽很清楚，数据应该如何表示却远未形成统一约定，人们对这个问题的理解甚至更少。一方面，数据可以任意预处理（例如，进一步分析前常先减去数据均值），因此已经具有一定自由度。另一方面，选择恰当的描述量来刻画研究对象本身就很困难：描述量过少可能遗漏对象的相关方面，过多则可能产生虚假相关，干扰我们希望从数据中得出的结论。每个数据点 $\mathbf{x}_i$ 的每个元素称为一个特征 (feature)。如前所述，正确表示数据及其特征是机器学习的核心问题，也是表示学习 (representation learning) 领域的中心。本书只会在若干处涉及它，例如分别通过第 7.2 节的自编码器与第 3 节的主成分分析。

最后强调，从宽泛意义上说，数据可以等同于经验：反复与某个实体（如实验或模拟）交互会产生数据，并让我们积累对其底层机制的一些经验。有时，这些经验又可用于继续与该实体交互并从中学习。为此，我们建立一个模型。总之，我们能够获取的数据类型，实际上规定了模型可能面对的学习类型。通常把它们分为三种：监督学习、无监督学习和强化学习。

监督学习 (supervised learning) 可视为第 1.4 节所述回归与分类的推广，它描述从带标签数据 $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}$ 学习的机器学习算法。监督学习方法从统计方法到第 2.4 节介绍的经典机器学习与深度学习，种类繁多。本书反复使用监督学习概念，它构成许多章节的基础，包括相分类（第 3 节）、高斯过程（第 4 节）及量子科学深度学习专题（第 8 节）。后一类中的一些方法尤其适合处理实验数据，例如高效读出量子点，或辨识描述量子实验装置的 Hamiltonian 参数。这些例子大多需要大量训练数据，但也有重要例外。除了数据本身，如上所述，监督学习还要求数据具有正确标签。这通常被视为它最突出的缺点之一，因为完全匹配的标签不一定能获得，或必须由人手工添加。

监督学习并非总是最佳选择；带标签数据稀缺时，经典输入—输出设计就可能失败。我们常常只能获得不附带标签等先验信息的数据，即 $\mathcal{D} = \{\mathbf{x}_i\}$ 。此时可以采用无监督学习 (unsupervised learning)。无监督学习既可以用于降维等初步预处理步骤，也可以用于聚类等表示学习。相反，还可利用生成模型添加特征，从而提高维数。本书讨论无监督学习在第 3 节相分类和第 7.2 节密度估计中的应用。前一个例子尤其有趣，因为它说明：当人们尚不理解某个过程，例如不知道相变两侧相的性质时，选择无监督而非监督学习，能够帮助自动发现新物理。

与前两类不同，强化学习（reinforcement learning, RL）通常根本没有现成数据集。我们面对的是一个环境，必须与其交互来完成某项任务。交互还伴随反馈，即关于某次行动有助于还是有害于完成任务的额外信息。所访问的环境状态、采取的行动以及收到的奖励或惩罚，共同扮演数据集的角色。反馈在强化学习中极为重要，因为完成任务没有清晰预定的路线。事实上，一开始我们通常连完成任务所需的要素都不知道；往往只知道自己实现了某个目标，却不知道为何能够实现。强化学习研究的正是如何解决这一问题。第 6 节将专章介绍它。

监督、无监督和强化学习是量子科学机器学习应用中最常见的方案，但也有超出这一分类的方法。一个有趣例子是主动学习（active learning）。它包括一类选择策略，使模型能在与人类专家或环境交互的过程中迭代构造训练集，目标是选出信息量最大的样本并尽量降低标注成本 [35, 36]。本书只会通过第 4.3 节的贝叶斯优化⁷以及第 3.5.3 节的学习边缘略作涉及。另一个例子是半监督学习（semi-supervised learning），它利用大量无标签数据获得更好的特征表示，并改进只用少量带标签数据训练的模型 [37]。

1.6 如何阅读本书

本书旨在以教学性且自洽的方式概述机器学习在量子科学中的现代应用。因此，第 2 节专门介绍机器学习预备知识，使读者能充分理解本书后续更高级的内容。我们详细讨论四种已在量子物理与化学中成功探索的主要机器学习范式：第 3 节说明如何用监督和无监督学习区分物态；第 4 节介绍核方法，重点讨论高斯过程和贝叶斯优化；第 5 节综述基于神经网络的多种量子态表示；最后，第 6 节深入介绍强化学习基础及其在量子实验中的应用。

除量子科学机器学习的这四大支柱外，自然科学与人工智能之间还存在令人振奋的双向相互作用。第 7 节侧重机器学习相关方法如何革新量子科学的较专门例子，特别介绍可微编程范式及其如何成为重要的数值研究工具。此外，我们讨论机器学习方法如何帮助研究者完成密度估计，以及科学实验的优化和加速。统计物理（见第 8.1 节）以及量子计算也反过来对机器学习产生着蓬勃影响。第 8.2 节介绍量子机器学习的前景。总体而言，本书讨论人工智能与物理科学之间富有成效的相互作用；图 1.3 标出了全书内容及相关章节。

建议读者先阅读前两章，即“引言”与“机器学习基础”。随后可自由选读第 3 至第 6 节涵盖的四种主要范式、第 7.1 节的可微编程，或第 8.1 节关于统计物理如何处理机器学习难题的讨论。第 7.2 节的生成模型以第 5 节神经网络量子态为基础；第 7.3 节实验机器学习需要了解第 3 节介绍的相分类方法；最后，第 8.2 节量子机器学习会使用第 4 至第 6 节引入的概念。图 1.4 以树形图展示各章依赖关系。

⁷贝叶斯优化与主动学习虽相似，却并不相同。主动学习旨在确定最优采样；贝叶斯优化旨在用尽可能少的函数求值找到黑箱函数的极值。




图 1.3: 本书内容. 我们涵盖三种主要学习方案——监督学习、无监督学习和强化学习; 分类、回归和密度估计等机器学习任务; 量子科学中的多种应用; 量子 and 经典机器学习架构; 并深入讨论机器学习原理.




图 1.4: 各章之间的依赖关系.

延伸阅读

- Carleo, G. 等 (2019), *Machine Learning and the Physical Sciences*, *Rev. Mod. Phys.* 91, 045002. 这篇详尽综述总结了截至 2019 年机器学习在物理学中的发展与成果 [5].
- Carrasquilla, J. (2020), *Machine Learning for Quantum Matter*, *Adv. Phys. X* 5, 1. 这篇简明综述侧重相分类和量子态表示 [6].
- Krenn, M. 等 (2023), *Artificial Intelligence and Machine Learning for Quantum Technologies*, *Phys. Rev. A* 107(1), 010101. 这篇观点文章关注量子计算、量子通信和量子模拟如何受益于机器学习革命 [38].
- Chollet, F. (2019), *On the Measure of Intelligence*. 该文回顾量化智能所用的不同度量, 为人工智能的发展提供一种视角 [39].
- Krenn, M. 等 (2022), *On Scientific Understanding with Artificial Intelligence*, *Nat. Rev. Phys.* 4, 761–769 [40]. 这篇精彩论文讨论人工智能能够以何种方式促进科学发现; 它涉及理解的哲学, 并从数十位科学家关于计算机辅助发现的轶事中得出结论.
- [量子物理与化学中的机器学习暑期学校课程录像](#). 该暑期学校于 2021 年 8 月 23 日至 9 月 3 日在波兰华沙举办.
- 为该暑期学校教程准备的 [Jupyter 笔记本](#) [2].

机器学习基础

本章介绍与优化和泛化有关的机器学习基本概念。此外，我们给出机器学习的概率观点，以处理预测中的不确定性。最后讨论各种机器学习模型。这些内容共同构成理解后续各章所需的机器学习预备知识。

2.1 作为优化问题的学习

机器学习可以解决分类或回归等多种任务，机器也可以通过不同方式访问数据。最后一个要素是一个能够利用现有数据学会解决给定任务的模型。一般而言，它是输入数据的函数 $f(\mathbf{x})$ ，输出被解释为针对该输入的预测。输出形式取决于任务：在分类任务中可以是离散候选类别集合中的一个类别，在回归任务中可以是来自连续目标分布的张量。针对特定任务寻找在数据与期望结果之间给出最佳映射的函数，是机器学习的核心。首先规定模型（函数）的某种参数化，例如 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + \mathbf{b}$ ，其中 $\theta \supset \{\mathbf{w}, \mathbf{b}\}$ 。该函数的一切可能参数化构成一个函数集合，即假设类（hypothesis class）。节 2.4 将给出假设类（或假设空间）的具体例子；目前我们只关注学习过程本身。

监督学习、无监督学习和强化学习方案具有同一个基本过程：在假设空间中寻找具有最优参数 θ^* 的最优模型 $\hat{f} \equiv f_{\theta^*}$ ，使目标损失函数最小或模型性能最大。为清楚起见，本节余下部分只讨论使损失函数（loss function） $\mathcal{L}$ 最小；直观上，它相当于对模型误差的惩罚。

机器通过使训练数据（即学习过程中机器学习模型可访问的全部数据）的损失函数最小来“学习”。最小化通过调节模型参数完成。损失函数的公式随任务而异，其选择具有一定自由度。一般而言，损失函数把模型预测或所求得解与现实或预期进行比较。因而，学习就成为一个优化问题。

依照文献 [13]，本书交替使用损失函数、误差函数和代价函数这些称呼¹。常见损失函数包括用于监督回归的均方误差（mean squared error, MSE）和用于监督分类的交叉熵（cross entropy, CE）²。

损失函数的输出取决于模型（通过预测值进入公式）和数据集。为比较不同数据集

¹文献中还使用准则、代价、误差或目标函数等称呼，它们的定义并不十分严格。文献 [13] 写道：“我们想要最小化或最大化的函数称为目标函数或准则。当使它最小时，也可以称其为代价函数、损失函数或误差函数。本书交替使用这些术语，尽管一些机器学习文献会赋予其中某些术语特殊含义”。例如，损失函数可能针对单个数据点定义，而代价函数或误差函数可能是损失函数之和，因此应该对每篇论文采用的定义。

²对于分类，更直观的性能度量可以是准确率，即正确分类样本数与数据集大小之比。但基于梯度的优化要求性能度量平滑且可微。这些条件把损失函数与准确率、召回率、精确率等评价指标区分开来。




图 2.1: 损失函数示例. (a) 单个数据点 x_i 的二元交叉熵曲线, 其中真实标签 $y_i = 0$ (蓝色) 或 1 (紫色). (b) 回归问题所用损失函数的直观含义. 虚线表示标签 y_i 与模型预测值 $f(x_i)$ 之差. (c) 单个数据点 x_i 在真实标签 $y_i = 0$ 时的均方误差 (紫色) 和平均绝对误差 (蓝色) 曲线.

大小的问题, 其值还按数据点数 n 归一化. 均方误差继承自线性回归问题, 定义为

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2. \quad (2.1)$$

它具有信息论解释, 详见节 2.4.1 和节 2.2. 前一小节还会介绍另一种可行的损失函数平均绝对误差 (mean absolute error, MAE); 如图 2.1(b)–(c) 所示, 它比均方误差对小误差更敏感. 交叉熵也源自信息论, 并与概率论有关 (见节 2.3). 二元分类可使用二元交叉熵 (BCE), 又称对数损失, 见式 2.2 及图 2.1(a); 多类分类则使用类别交叉熵 (CCE). 二者定义为

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_{i=1}^n [y_i \log f(\mathbf{x}_i) + (1 - y_i) \log(1 - f(\mathbf{x}_i))], \quad (2.2)$$

$$\mathcal{L}_{\text{CCE}} = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^K y_{i,c} \log f(\mathbf{x}_i). \quad (2.3)$$

其中 K 是类别数. 该公式要求用独热编码 (one-hot encoding) 表示标签. 在有 K 个类别的问题中, 不再令标签取 $y_i = 1, 2, \dots, K$, 而把每个标签编码为一个 K 维向量: 除对应类别的索引处为 1 外, 其余分量全为 0. 例如 $\mathbf{y}_i = [0, 0, 1, \dots, 0]$ 表示样本 i 属于第三类, 因为只有 $y_{i,3}$ 非零.

选定损失函数后, 就可以采用任意优化方法, 通过改变机器学习模型的参数使其最小. 一般而言, 可以用解析构造, 或用基于梯度或无梯度的优化方法求得最小值. 一种常见的梯度方法是梯度下降 (gradient descent). 优化通常从损失景观中的随机位置开始, 即从参数随机初始化为 $\boldsymbol{\theta} = \boldsymbol{\theta}_0$ 的模型开始³. 用参数为 $\boldsymbol{\theta}_0$ 的模型对训练数据作出

³实践中通常随机初始化参数, 但会约束各层参数均值为零且方差恒定, 否则可能遇到梯度消失或梯度爆炸问题 [41].




图 2.2: 学习率的选择会影响向最小值的收敛. (a) 若 η 太小, 训练需要许多轮次. (b) 合适的 η 可以快速收敛到一个最小值, 但需要设法确定. (c) 若 η 太大, 优化可能反而远离最小值, 即发生“越过”. 图中把损失函数画成了凸函数, 但实际中很少如此.

预测, 并据此计算损失函数; 接着计算损失函数对每个模型参数 θ_j 的梯度; 最后将各参数减去相应梯度与学习率 (learning rate) η 的乘积, 即

$$\theta_j := \theta_j - \eta \frac{\partial \mathcal{L}}{\partial \theta_j}. \quad (2.4)$$

这些步骤必须反复执行直至到达最小值, 每次重复称为一个轮次 (epoch). 梯度下降沿函数值减小的方向更新模型参数, 即沿与梯度相反的方向迈步; 学习率控制步长. 图 2.2 以简化方式说明了选择 η 的重要性. 它过大或过小都会使优化更困难, 只有适当的值才有望高效收敛到最小值. 学习率通常没有显然的选择方法, 必须例如通过试错确定, 因此它是学习过程的超参数 (hyperparameter) 之一. 超参数控制学习过程, 尤其控制收敛速度和所得最小值的质量, 并由用户选择; 模型参数则通过训练得到. 总轮次数和损失函数的选择也都是超参数. 本章还会遇到更多例子.

为寻找最优超参数, 除了训练数据集外还应另设一个验证数据集 (validation data set). 这些数据只用于验证模型, 不用于训练. 随后可设置不同超参数, 并选择使验证集误差最小的取值⁴. 数据量有限时, 把数据集划分成更小的子集可能产生问题. 其他方法包括 k 折交叉验证 (cross-validation) [13]: 把数据集划分为 k 个互不重叠的子集, 进行 k 次试验, 第 i 次以第 i 个子集为验证集、其余为训练数据, 最后取误差平均值来估计验证误差. 交叉验证的代价是计算成本增加.

回到梯度下降, 在每一步之前必须先计算损失函数对待调参数的梯度 $\nabla_{\theta} \mathcal{L}$, 见式 2.4. 原则上有若干计算方法: 可以手工推导解析导数, 也可以用有限差分作数值近似. 当关心导数的精确数值而非符号形式时, 自动微分 (automatic differentiation, AD) 是很好的选择. 自动微分利用如下事实: 计算损失函数的程序可分解为少数基本算术运算 (如加法或乘法) 与函数 (如指数或正弦) 的序列. 因此, 反复应用链式法则等预先

⁴甚至可以用优化方法寻找使验证误差最小的超参数; 常用工具库之一是 Optuna [42]. 不过, 以直觉指导超参数选择可能更快、成本更低.

算法 1 小批量随机梯度下降 (SGD)

输入: 学习率 η

将 θ 初始化为随机值

for epoch = 1 **到** no_epochs **do**

打乱 $\mathcal{D}_{\text{train}}$

for $i = 1$ **到** m (m 为小批量大小) **do**

$\mathbf{x}_i, y_i \sim \mathcal{D}_{\text{train}}$

▷ 从数据集中无放回地随机抽取数据点

$\mathcal{L} \leftarrow \frac{1}{m} \sum_{i=1}^m \mathcal{L}(y_i, f(\mathbf{x}_i))$

▷ 计算小批量上的损失函数

$(\nabla \mathcal{L})_j \leftarrow \frac{\partial \mathcal{L}}{\partial \theta_j}$

▷ 计算梯度

$\theta_j \leftarrow \theta_j - \eta \frac{\partial}{\partial \theta_j} \mathcal{L}$

▷ 更新参数

end for

end for

返回 θ

定义的基本微分规则，就可自动算出程序导数的数值：

$$\frac{df(g(x))}{dx} = f'(g(x))g'(x). \quad (2.5)$$

关于计算机程序导数、尤其自动微分的更多细节，见[节 7.1⁵](#)。

上述优化过程在损失景观 (loss landscape) 为凸时非常高效；损失景观是模型参数空间周围损失值的表示。但尤其对深度学习而言，损失景观高度非凸，且通常有多个局部极小值 [43, 44]。这立即引出两个问题：如何避免陷入损失较大的局部极小值或鞍点？某些极小值是否优于另一些？有关学习动力学的问题仍在探索，但统计物理已给出一些直觉（见[节 8.1](#)）。常用方法是对梯度下降稍作修改，得到随机梯度下降 (stochastic gradient descent, SGD) [45]。其伪代码见[算法 1](#)：每个轮次用从训练数据随机选取的小批量计算损失函数。因而各轮次的梯度可能指向不同方向。事实证明，由此产生的随机性有助于逃离鞍点和狭窄局部极小值 [46]⁶。此外，只对小批量而非整个数据集计算损失函数和梯度，可以显著加速大型数据集的计算。

下面更细致地考察深度学习模型优化所到达的极小值。为描述极小值附近的曲率，使用训练损失函数的 Hessian 矩阵 (Hessian)

$$\mathbf{H}_{\theta^*} = \frac{\partial^2}{\partial \theta_i \partial \theta_j} \mathcal{L}_{\text{train}} \Big|_{\theta=\theta^*},$$

即损失函数对模型参数的二阶偏导数构成的方阵，并在极小值 $\theta = \theta^*$ 处求值。最大正特征值对应的特征向量指明极小值附近上升最陡的方向。高曲率意味着训练数据在该方向上强烈决定模型参数。或许令人意外的是，训练会到达局部极小值或鞍点⁷ [49, 50, 51]：

⁵把自动微分以反向模式 (reverse mode) 应用于神经网络的特殊情形称为反向传播；它是实现神经网络高效训练的主力方法。

⁶实践中随机性有助于避开鞍点，但理论工作表明它并非正确收敛的必要条件 [47]。

⁷人们可能会问：模型没有落在全局极小值，为什么还值得信任？经验结果以及把自旋玻璃理论应用于深度学习的研究 [48] 表明，大型网络中的多数局部极小值彼此等价，并在测试集上给出相近性能。对小

绝大多数特征值接近零，表明存在多个平坦方向；还有一些较小的负特征值，表明存在负曲率方向。节 3.5.3 将给出从 $\mathbf{H}_{\theta^*}$ 中获取信息的更多例子。

至此介绍的唯一一种基于梯度的优化方法是随机梯度下降。常见改进包括加入考虑先前更新方向的动量项（momentum term）[52, 53]，在不同轮次采用自适应学习率（adaptive learning rate）[54]，或兼用二者；著名的 Adam 优化器正是后一类方法[55, 56]。另一思路是把二阶导数纳入更新规则，L-BFGS 算法即采用这种方法[57]。还有无梯度优化方法，尤其适用于梯度或损失函数本身计算代价高昂或无法计算的情形，例如实验优化。例子包括遗传算法、粒子群优化、随机搜索和模拟退火[58]。节 4.3 将更详细讨论另一个例子——贝叶斯优化（Bayesian optimization, BO）。

2.2 泛化与正则化

到目前为止，机器学习看起来或许只是披着外衣的函数拟合。一旦不再只追求模型在现有数据上的性能最大化，情形就发生了变化。

机器学习的核心在于泛化（generalization），即对训练期间从未见过的新数据作出准确预测的能力。

泛化能力可以用泛化误差（generalization error）量化。它是模型面对实践中预期会遇到的输入-输出对分布所生成的新数据时的期望误差[13]。然而，这种分布通常无法获得。因此，用模型在一个额外留出数据集上的表现来近似泛化误差；这个数据集称为测试集（test set），其中的数据点既不用于优化模型参数，也不用于寻找刻画学习过程的最佳超参数。测试集上的误差称为测试误差，它是衡量模型泛化能力的可操作指标，并且只用于报告模型的最终性能⁸。原始数据集需要分成训练集、验证集和测试集⁹。准备数据集时必须格外谨慎，以防止信息泄漏（information leakage），即训练过程使用了预测时预期无法获得的信息¹⁰。还要注意，我们始终假设所有数据点均独立地抽取自同一分布¹¹。这保证样本彼此不相关，也保证数据集可以划分为较小子集。

训练机器学习模型时，一个常见现象是测试误差高于训练误差。两者之差可作为泛化差距（generalization gap）的代理量；泛化差距严格指训练误差与泛化误差之差。即使所有数据点由同一个概率分布生成，测试集性能低于训练集的现象仍然存在，且只在无限数据极限下消失。主要原因是深度学习模型的高容量（capacity）¹²。

型网络而言，找到“坏的”（取值高的）局部极小值的概率非零，但随网络规模增大而迅速下降。最后，在训练集上寻找全局极小值在实践中并无益处，反而可能导致过拟合，即训练集性能远好于测试集性能，这等价于泛化不佳。

⁸之所以需要测试集，是因为我们用验证集寻找最佳超参数，故验证集上评估的性能可能被高估。

⁹这些集合的大小比例取决于总数据量；可以从例如 8 : 1 : 1 开始。

¹⁰常见错误是先归一化整个数据集，再把它划分为训练集、验证集和测试集。归一化包含最极端数据点的信息，而这些点甚至可能不在训练集中。模型可利用这种信息在现有数据上取得更好表现，因而报告的测试误差未必忠实反映模型在未见数据上的性能。

¹¹实践中，模型可能遇到来自不同于训练样本生成分布的样本。此时模型往往过度自信[59]，因而不可靠。所以，检测分布外样本是把机器学习部署到安全关键型应用时的一项核心挑战。

¹²深度学习模型甚至可以拟合带有随机标签的大型数据集[60]！




图 2.3: 欠拟合与过拟合示意图. (a) 模型容量太低时, 模型无法正确拟合训练数据. (b) 模型容量与任务复杂度相称时, 拟合最优. (c) 模型容量超过任务复杂度时, 模型倾向于过拟合, 泛化误差增大.

容量可以宽泛地理解为模型拟合多种函数的能力度量. 当模型容量远高于解决任务所需的容量时, 模型倾向于过拟合 (overfitting), 即记住训练集的一切可能属性, 而这些属性对一般分布、特别是测试集未必成立.

模型甚至可能拟合训练数据中的噪声. 因此, 过拟合会在保持训练误差较低 (甚至继续降低) 的同时增大测试误差. 最优容量给出最低泛化误差, 并使测试误差与训练误差之间的差距最小. 但容量太低会造成约束过强的模型, 使其欠拟合 (underfitting), 即训练误差也很高. 图 2.3 示意了欠拟合与过拟合背后的直觉. 因而, 可以通过控制模型容量改善其泛化.

任何旨在改善模型泛化的修改, 即便代价是增大训练误差, 都称为一种正则化 (regularization) 技术.

可以用奥卡姆剃刀来理解正则化¹³. 另一动机是没有免费午餐定理 (no free lunch theorem). 该定理指出, 对所有可能的数据生成分布取平均时, 每一种分类算法在分类先前未见点时都有相同的错误率 [13, 61]. 因而, 没有任何模型或正则化技术普遍优于另一种. 必须把算法设计成在特定任务上表现良好, 例如采用针对该任务定制的正则化.

限制模型容量的一种直接方法是限制可训练参数的大小, 这实际上限制了参数化模型的假设空间. 可以在训练损失函数中加入一个随参数大小增大的惩罚项. 两种常见技术 ℓ_1 和 ℓ_2 正则化采用这种方法. 尤其是 ℓ_2 正则化, 将在节 2.4.1 和节 4.2.1 中更详细地说明.

以上只是直观讨论模型复杂度与其在训练集、测试集上性能的关系. 下面用偏差-方差权衡 (bias-variance trade-off) 把这种直觉形式化. 考虑回归问题中的标准情形: 给定数据点系综 $\mathcal{D} = \{\mathbf{x}, f(\mathbf{x}) + \epsilon\}$, 它来自函数 $f(\mathbf{x})$ 以及数据中固有的噪声 ϵ . 函数 $f(\mathbf{x})$

¹³该原则说, 在能够同样好地解释已知观测的相互竞争假设中, 应选择最简单者; 常概括为“如无必要, 勿增实体”.

通常未知，目标是推断它。为此，对数据构造回归拟合 $\hat{f}(\mathbf{x})$ 。最终关心的是使测试误差（或泛化误差）尽可能小。对固定训练集 $\mathcal{T}$ ，测试误差是测试点上损失函数 $\mathcal{L}$ 的平均：

$$\text{Err}_{\mathcal{T}} = \mathbb{E}[\mathcal{L}(\mathbf{y}, \hat{f}(\mathbf{x})) \mid \mathcal{T}]. \quad (2.6)$$

这个量很难计算，可以转而使用在许多训练集上对泛化误差取平均所得的期望预测误差：

$$\text{Err} = \mathbb{E}[\mathcal{L}(\mathbf{y}, \hat{f}(\mathbf{x}))] = \mathbb{E}[\text{Err}_{\mathcal{T}}]. \quad (2.7)$$

考察给定点 $\mathbf{x}_0$ 处的期望预测误差：

$$\text{Err}(\mathbf{x}_0) = \mathbb{E}[(f(\mathbf{x}_0) + \epsilon - \hat{f}(\mathbf{x}_0))^2]. \quad (2.8)$$

这里暂以均方误差作为损失函数，见式 2.1。式 2.8 中的平均遍及 $\mathbb{E}[\cdot]$ 内部的一切随机变量，即噪声 ϵ ，以及因选取不同训练集而变化的模型。展开得

$$\text{Err}(\mathbf{x}_0) = \mathbb{E}[(f(\mathbf{x}_0) - \hat{f}(\mathbf{x}_0))^2] + \mathbb{E}[2\epsilon(f(\mathbf{x}_0) - \hat{f}(\mathbf{x}_0))] + \mathbb{E}[\epsilon^2]. \quad (2.9)$$

其中 $\mathbb{E}[\epsilon^2]$ 是数据底层噪声的固定方差。利用独立随机变量的性质 $\mathbb{E}[AB] = \mathbb{E}[A]\mathbb{E}[B]$ ，得到

$$\mathbb{E}[2\epsilon(f(\mathbf{x}_0) - \hat{f}(\mathbf{x}_0))] = 2\mathbb{E}[\epsilon]\mathbb{E}[f(\mathbf{x}_0) - \hat{f}(\mathbf{x}_0)] = 0, \quad (2.10)$$

这里假设噪声无偏，即 $\mathbb{E}[\epsilon] = 0$ 。因而只剩

$$\mathbb{E}[(f(\mathbf{x}_0) - \hat{f}(\mathbf{x}_0))^2] + \mathbb{E}[\epsilon^2] = \mathbb{E}[\hat{f}(\mathbf{x}_0)^2] - 2f(\mathbf{x}_0)\mathbb{E}[\hat{f}(\mathbf{x}_0)] + f(\mathbf{x}_0)^2 + \mathbb{E}[\epsilon^2]. \quad (2.11)$$

在式 2.11 中同时加上和减去 $\mathbb{E}[\hat{f}(\mathbf{x}_0)]\mathbb{E}[\hat{f}(\mathbf{x}_0)]$ ，可得

$$\begin{aligned} \text{Err}(\mathbf{x}_0) &= \left(\mathbb{E}[\hat{f}(\mathbf{x}_0)] - f(\mathbf{x}_0)\right)^2 \\ &\quad + \left(\mathbb{E}[\hat{f}(\mathbf{x}_0)^2] - \mathbb{E}[\hat{f}(\mathbf{x}_0)]\mathbb{E}[\hat{f}(\mathbf{x}_0)]\right) + \mathbb{E}[\epsilon^2]. \end{aligned} \quad (2.12)$$

第一项是模型的偏差平方：

$$\text{Bias}^2[\hat{f}(\mathbf{x}_0)] := \left(\mathbb{E}[\hat{f}(\mathbf{x}_0)] - f(\mathbf{x}_0)\right)^2, \quad (2.13)$$

第二项是它的方差：

$$\text{Var}[\hat{f}(\mathbf{x}_0)] := \mathbb{E}[\hat{f}(\mathbf{x}_0)^2] - \mathbb{E}[\hat{f}(\mathbf{x}_0)]\mathbb{E}[\hat{f}(\mathbf{x}_0)]. \quad (2.14)$$

于是

$$\text{Err}(\mathbf{x}_0) = \text{Bias}^2[\hat{f}(\mathbf{x}_0)] + \text{Var}[\hat{f}(\mathbf{x}_0)] + \mathbb{E}[\epsilon^2]. \quad (2.15)$$

因此，给定未见测试点 $\mathbf{x}_0$ 处的平均预测误差，可以分解为模型偏差、模型方差和数据底层噪声的方差；最后一项从模型角度看不可约¹⁴。




图 2.4: 偏差-方差权衡及其与训练集（绿色曲线）和测试集（红色曲线）预测误差关系的示意图. 理想模型给出最低测试误差, 同时具有中等的模型复杂度（例如容量）和训练误差. 改编自文献 [63].

模型 $\hat{f}(\mathbf{x})$ 越复杂, 训练后的偏差越小. 然而, 增大的模型复杂度通常也使其在捕捉数据点时产生更大波动, 从而导致更大方差——这种情形称为过拟合. 这就是偏差-方差权衡.

图 2.4 展示了偏差-方差权衡, 清楚表明理想模型在训练误差与模型复杂度之间实现最优折中. 有趣的是, 经验研究显示, 容量巨大的现代大型深度学习模型也能很好地泛化 [64]. 过参数化模型为何能够如此良好地泛化, 仍是该领域的一项棘手谜题¹⁵; 统计物理工具则给出了一些见解（见节 8.1）.

2.3 机器学习的概率观点

当我们考虑机器学习必须处理的三种不确定性来源时, 概率方法的必要性便显而易见（依照文献 [13]）. 第一, 生成可用数据的系统可能具有内禀随机性, 处理量子数据时尤其如此. 第二, 必须计及可能存在的不完全可观测性, 即不可避免地缺少有关所有影响系统的变量的信息¹⁶. 换言之, 借助现有数据, 我们只能部分接触系统底层机制或分布的一切相关部分. 最后, 所用模型很少是完备的, 因而必须舍弃一部分可用信息. 不完备建模的一个例子是把机器人的运动空间离散化; 这种离散化立即使机器人对空间中

¹⁴这并非只对均方误差损失成立; 偏差-方差分解有许多变体 [62].

¹⁵彩票假设提供了一些很有希望的观点 [65].

¹⁶这其实是特性而非缺陷. 例如, 由于地球与太阳的引力相互作用, 我们很容易理解地球绕太阳的运动; 但要预测地球的精确轨道, 还必须计及太阳系内所有其他引力质量. 除非打算把卫星送入太空, 否则我们很乐于忽略这些相互作用, 只承受预测中的一个小误差.

“被省略的”区域产生不确定性. 为在数学上计及模型的不确定性, 可以遵循概率的贝叶斯方法: 把概率解释为对某种信念 (belief) 的预期或量化.

下面简要回顾本书后文会用到的概率论基本概念:

- 不追求数学上的严格性, 随机变量 (random variable) 就是取随机值的变量. 如果一组随机变量相互独立且同分布, 即从同一概率分布独立抽取, 就称为独立同分布 (independent and identically distributed, i.i.d.) 随机变量.
- 概率分布 (probability distribution) 衡量随机变量 X 取各个可能状态 x 的可能性¹⁷, 例如 $p(X = x)$. 离散(连续)变量上的概率分布称为概率质量函数 (probability mass function)(概率密度函数 (probability density function)). 联合概率分布 (joint probability distribution) 是多个变量上的概率分布, 例如记为 $p(X = x, Y = y)$. 记号含义明确时, 通常也省略随机变量, 写成 $p(X = x) \equiv p(x)$.
- 若两个随机变量 X 和 Y 的联合概率分布可写为两个因子的乘积, 其中一个只涉及 X , 另一个只涉及 Y , 则称二者独立 (independent):

$$\forall x, y, \quad p(X = x, Y = y) = p(X = x)p(Y = y). \quad (2.16)$$

这种独立性可记作 $X \perp Y$.

- 元素由随机变量组成的向量称为随机向量 (random vector), 直接记为 $\mathbf{x}$.
- 条件概率 (conditional probability) 是在另一事件已经发生的条件下某事件发生的概率. 记 $p(Y = y | X = x)$, 表示观测到 $X = x$ 时 $Y = y$ 的概率. 它可计算为

$$p(Y = y | X = x) = \frac{p(Y = y, X = x)}{p(X = x)}. \quad (2.17)$$

- 多个随机变量上的任何联合概率分布都可以分解为各自只针对一个变量的条件分布; 这称为概率的链式法则 (chain rule) 或乘积法则 (product rule):

$$p(x^{(1)}, \dots, x^{(n)}) = p(x^{(1)}) \prod_{i=2}^n p(x^{(i)} | x^{(1)}, \dots, x^{(i-1)}). \quad (2.18)$$

- 最后, 考虑已知条件概率 $p(y | x)$ 而需要反向条件概率 $p(x | y)$ 的情形. 如果还知道 $p(x)$, 就可用Bayes 规则 (Bayes' rule) 计算:

$$p(x | y) = \frac{p(y | x)p(x)}{p(y)}. \quad (2.19)$$

Bayes 规则是式 2.17 中条件概率定义的直接推论. 若不知道 $p(y)$, 可通过 $p(y) = \sum_x p(y | x)p(x)$ 计算; 这就是概率的求和法则 (sum rule). 回到贝叶斯统计中的信念概念, 还可清楚解释式 2.19 的其他各项. 在该理论中, $p(x)$ 编码关于命题 x 的先验知识, 也就是尚未纳入任何已收集证据 y 时的模型, 因此称为先验

¹⁷这一记号很容易推广到向量值随机变量.

(prior). Bayes 规则说明如何用似然 (likelihood) $p(y | x)$ 更新信念, 从而得到后验 (posterior) $p(x | y)$. 后验建模的是已计及所收集证据 y 后关于命题 x 的更新知识.

现在已有足够工具从概率角度考察机器学习模型, 特别是重新表述监督学习和无监督学习. 无监督学习观察随机变量 X 的若干结果, 例如 $x_1, x_2, \dots, x_n$, 然后学习概率分布 $p(X)$ 或其某些性质¹⁸. 监督学习则观察随机变量 X 的实例和相应变量 Y , 例如 $\{x_1, y_1\}, \{x_2, y_2\}, \dots, \{x_n, y_n\}$, 并学习从 x 预测 y , 通常是从数据估计 $p(Y = y | X = x)$. 所谓 Bayes 分类器 (Bayes classifier) 以真实条件概率 $p(Y = y | X = x)$ 为预测依据, 即给定样本 x 后预测标签 $y_{\text{Bayes}} = \arg \max_y p(y | X = x)$. 它是最优的, 因为在该分类任务中不存在误分类概率更低的其他分类器 [66]. 但 Bayes 分类器仍可能出错, 其误分类概率可能非零. 这一不可约误差称为 Bayes 误差 (Bayes error), 是所考虑分类任务的固有限制, 与预测模型的选择无关. 若存在相同样本 x 被赋予不同标签 y , 使类条件概率 $p(y | X = x)$ 不等于 0 或 1, 分类问题就具有非零 Bayes 误差.

下面把这种概率观点与节 2.1 中把学习视为优化任务的观点结合起来. 上述讨论表明, 机器学习模型用于根据数据估计概率分布. 因为模型通常是参数化的, 所以必须引入似然概念. 似然函数 (likelihood function) 是观测数据的联合概率, 把它视作所选模型参数的函数, 即 $p(\mathcal{D} | \theta)$; 该模型估计数据生成概率分布¹⁹. 似然提供了给定数据与待学习模型参数之间缺失的联系. 为此, 考虑如何比较同一随机变量 X 上的两个概率分布, 例如 $p(x)$ 和 $q(x)$. 可用度量之一是称为相对熵 (relative entropy) 的 Kullback–Leibler 散度 (Kullback–Leibler divergence, KL divergence) $D_{\text{KL}}(p||q)$. 准确地说, 它衡量分布 q 与参考分布 p 的差异. 本书通常在分类任务中使用它, 此时 p 与 q 都是离散变量的分布, 定义为

$$D_{\text{KL}}(p||q) = \mathbb{E}_p \left[\log \frac{p(x)}{q(x)} \right] = \frac{1}{n} \sum_i^n p(x_i) \log \frac{p(x_i)}{q(x_i)}. \quad (2.20)$$

对于连续分布, 应以积分代替求和. $D_{\text{KL}}(p||q)$ 具有距离的一些性质: 它非负, 并且当且仅当 p 与 q 相等时为零²⁰. 但它并非真正的距离度量, 因为它不对称: $D_{\text{KL}}(p||q) \neq D_{\text{KL}}(q||p)$ ²¹. 利用对数性质, 可写成

$$D_{\text{KL}}(p||q) = \frac{1}{n} \sum_i^n p(x_i) \log p(x_i) - \frac{1}{n} \sum_i^n p(x_i) \log q(x_i) := -\mathcal{S}(p) + \mathcal{L}_{\text{CE}}(p, q). \quad (2.21)$$

其中 $\mathcal{S}(p)$ 是参考概率分布 p 的 Shannon 熵, 第二项则正是式 2.2 和式 2.3 中已经介绍的交叉熵. 由于 q 不出现在 $\mathcal{S}(p)$ 中, 使 $D_{\text{KL}}(p||q)$ 最小等价于使交叉熵最小.

比较概率分布对用参数化分布估计未知分布显然有用, 但对任意机器学习模型的用途可能并不立即显见. 考虑使用模型 f 的监督学习. 带标签训练集由 n 个二元组 $\{x_i, y_i\}$

¹⁸这个概念同样很容易推广到随机向量.

¹⁹不要混淆似然与概率. 直观上, 概率是来自某个分布的样本的性质, 而似然是参数化模型的性质. 特别地, 把 $p(\mathcal{D} | \theta)$ 画成可能参数 θ 的函数时, 它对参数的积分不必为 1.

²⁰对离散变量指处处相等; 对连续变量指“几乎处处”相等, 即除一个零测集外, 在整个相关空间都相等.

²¹关于 $D_{\text{KL}}(p||q)$ 不对称性的直观讨论, 推荐文献 [13] 第三章的第六幅图.

构成, 其中 x_i 是标签为 y_i 的样本, 每个标签属于 K 个类别之一. 可把独热编码标签 $y_i = k$ 看成一个非常特殊的概率分布 $y_i = q(x_i) = \delta_{k,j}$, 其中 $k, j \in \{1, \dots, K\}$. 把训练数据 x_i 输入模型 f 后, 得到概率分布 $p(x_i) = f(x_i)$, 它给出样本 x_i 属于各类别的概率. 最后必须比较 p 与 q 两个概率分布, 于是重新得到式 2.3 中的类别交叉熵. 类似地, 也可以证明式 2.1 中的均方误差损失会从概率观点自然出现; 相关分析见节 2.4.1 的线性回归例子. 总之, 概率论与机器学习的优化观点之间存在深刻联系.

2.4 机器学习模型

机器学习的三个要素中, 我们已经介绍了两个: 任务 (节 1.4) 和数据 (节 1.5). 最后一个要素是利用数据学会解决任务的模型. 机器学习模型大体可分为标准机器学习与深度学习两类. 节 2.4.1 至节 2.4.3 概述前者, 节 2.4.4 至节 2.4.6 则更深入地说明后者.

如图 1.2 所示, 深度学习本身是机器学习的一个子领域. 但惯例上会按方法是否使用神经网络来区分机器学习方法. 因此, 本章余下部分把任何不使用神经网络的算法称为标准机器学习 (standard machine learning).

这种区分还有更细微之处. 简言之, 传统学习与深度学习的差别, 在于抽取特征时的抽象层次和算法灵活性. 传统机器学习需要针对手头问题设计和定制非常具体的算法, 模型选择往往取决于经验以及对任务的进一步直觉. 神经网络则是灵活而通用的工具, 主要目标是在几乎不约束搜索函数类的情况下复现目标函数. 缺点是, 与传统方法相比, 其映射通常不易解释, 因而常被称为黑箱函数 (black-box function). 节 3.5 将说明这种说法在多大程度上成立. 可以得到的区别是: 深度学习不要求显式规定如何连接输入与输出; 传统机器学习方法则往往由几何或信息论论证构造, 其构造本身已提供方法直觉, 因而具有直接可解释性.

自然会问: 应选择传统机器学习还是深度学习? 答案一如既往: 视情况而定. 在大数据区间, 神经网络有足够信息推断并实施特征抽取, 深度学习能达到最先进水平. 在低数据极限下, 传统机器学习仍占优势; 此时必须把尽可能多的信息纳入所选算法以提高学习效率, 因此算法通用性降低, 对问题的依赖增强.

下面先关注标准机器学习算法, 把神经网络留到节 2.4.4 及后续内容讨论. 本书会遇到的一些突出传统方法包括: 主成分分析 (principal component analysis, PCA) 是一种优雅的降维即数据压缩方法, 它压缩多维样本的特征空间, 只保留少数相关特征; 压缩后的数据可继续进入其他机器学习流程 (见节 3.2.1). 高斯过程 (Gaussian processes, GPs) 则很适合可用数据有限的学习任务. 它与贝叶斯优化共同构成变分推断最有力的例子之一 (见章 4), 也是强大且应用广泛的核方法 (kernel methods) 实例. 其精妙之处在于高效地对输入数据应用特征变换, 把难以分析的表达映射到更易分析的域中.

这些方法将在全书各处详细讨论. 以下内容是标准机器学习模型的入门介绍, 从线性回归、逻辑回归和线性支持向量机等基本方法开始, 进而进入深度学习领域, 介绍神经网络, 并重点讨论卷积神经网络和自回归神经网络.

2.4.1 线性 (岭) 回归

在深入细节之前, 先重述[节 1.4](#) 概述的回归问题. 给定带标签数据集

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \equiv \{(\mathbf{X}, \mathbf{y})\},$$

其中观测来自底层函数 f , 并可能受到某种随机噪声 ϵ 的影响. 通常假设噪声从未知噪声分布 $\mathcal{E}$ 中抽取, 即 $\epsilon \sim \mathcal{E}$:

$$y_i = f(\mathbf{x}_i) + \epsilon_i, \quad \forall (\mathbf{x}_i, y_i) \in \mathcal{D}. \quad (2.22)$$

函数 f 通常未知, 目标是推断它. 为此, 构造数据的回归拟合 $\hat{f}$, 使 $\hat{f}(\mathbf{x}) \approx y$ ²².

可以说, 最简单的参数化拟合方法是线性模型 (linear model). 我们寻找参数 $\boldsymbol{\theta} \in \mathbb{R}^d$, 使输入变量 $\mathbf{x}$ 与预测 $\hat{y}$ 线性相连:

$$\hat{y} = \sum_{i=1}^{d-1} \theta_i x_i + b \equiv \sum_{i=0}^{d-1} \theta_i x_i = \mathbf{x}^\top \boldsymbol{\theta}. \quad (2.23)$$

为缩短记号, 通过设 $x_0 = 1$, 把常数 $\theta_0 = b$ (所谓偏置 (bias)) 吸收到输入 $\mathbf{x}$ 的定义中. 此时线性模型旨在寻找穿过数据点的一个超平面²³. 可用输入的非线性变换 ϕ 扩展模型, 即 $\mathbf{x} \mapsto \phi(\mathbf{x})$. 因为对待优化参数 $\boldsymbol{\theta}$ 仍保持线性, 这依然是线性回归. 例如, 非线性变换 $\phi_p: \mathbf{x} \mapsto (1, x, x^2, x^3, \dots, x^p)$ 把模型提升为最高 p 次的多项式回归. 为简化本小节其余记号, 下面考虑不应用特征映射的情形. 特征映射是[章 4](#) 的核心要素, 届时会更充分地讨论.

用参数 $\boldsymbol{\theta}$ 定义某个超平面后, 需要规定一个质量度量, 把预测与相应真实值进行比较, 即选择合适的损失函数 $\mathcal{L}$. 最常规的选择是数据集 $\mathcal{D}$ 上的均方误差:

$$\mathcal{L}_{\text{MSE}}(\boldsymbol{\theta} \mid \mathcal{D}) := \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\theta})^2 = \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2. \quad (2.24)$$

为得到最右边的等式, 把所有输入 $\mathbf{x}_i$ 逐个竖直堆叠, 形成矩阵 $\mathbf{X} \in \mathbb{R}^{(d-1) \times n}$; 对 y_i 作同样处理得到 $\mathbf{y}$. 随后可求使均方误差最小的参数集, 得到最小二乘估计量 (least-squares estimator, LSE) (推导见 [Appendix B](#) 前半部分):

$$\boldsymbol{\theta}_{\text{LSE}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{X}^+ \mathbf{y}. \quad (2.25)$$

其中 $\mathbf{X}^+$ 表示 Moore–Penrose 逆 (Moore–Penrose inverse) [\[67\]](#).

选择均方误差似乎不言自明. 实际上, 可以通过最大化给定模型参数时带标签数据的似然 $p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta})$ 推导它. 假设目标 y 实际从一个高斯分布抽取, 其均值由线性模型 $\mathbf{x}^\top \boldsymbol{\theta}$ 给出, 方差 σ^2 则描述数据噪声. 在给定位置 $\mathbf{X}$ 和模型参数 $\boldsymbol{\theta}$ 时, 观测目标 $\mathbf{y}$ 的似然为

$$p(\mathbf{y} \mid \mathbf{X}, \boldsymbol{\theta}) = \mathcal{N}(\mathbf{y} \mid \mathbf{X}^\top \boldsymbol{\theta}, \sigma^2 \mathbf{1}) \quad (2.26)$$

$$= \prod_{i=1}^n \mathcal{N}(y_i \mid \mathbf{x}_i^\top \boldsymbol{\theta}, \sigma^2). \quad (2.27)$$

²²为简单起见, 这里考虑一维输出; 以下推导也很容易推广到多维输出.

²³对一维输入和输出, 超平面就是一条直线.

最后一步还假设 $\mathcal{D}$ 由独立同分布随机变量组成，从而把多元高斯分布因子化. 通常把观测数据集 $\mathcal{D}$ 看成底层线性模型最可能生成的数据集，因此寻找产生最可能数据的参数. 这就是最大似然估计 (maximum likelihood estimation, MLE). 其估计量定义为式 2.26 似然最大值的宗量. 加入对数后得到

$$\boldsymbol{\theta}_{\text{MLE}} := \arg \max_{\boldsymbol{\theta}} p(\mathbf{y} | \mathbf{X}, \boldsymbol{\theta}) \quad (2.28)$$

$$= \arg \max_{\boldsymbol{\theta}} \log p(\mathbf{y} | \mathbf{X}, \boldsymbol{\theta}) \quad (2.29)$$

$$= \arg \max_{\boldsymbol{\theta}} \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\theta})^2 + \text{const.} \right] \quad (2.30)$$

$$= \arg \min_{\boldsymbol{\theta}} \left[\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\theta})^2 \right] \equiv \arg \min_{\boldsymbol{\theta}} (\mathcal{L}_{\text{MSE}}). \quad (2.31)$$

式 2.30 中的常数与 $\boldsymbol{\theta}$ 无关，可以忽略. 因而，独立同分布假设与最大似然估计共同导出均方误差这一首选损失函数；最大似然估计量 $\boldsymbol{\theta}_{\text{MLE}}$ 与式 2.25 的最小二乘估计量 $\boldsymbol{\theta}_{\text{LSE}}$ 重合.

但该估计量完全忽略了 σ^2 所描述的数据噪声，因为它也在最大化 $p(\mathbf{y} | \mathbf{X}, \boldsymbol{\theta})$ 时消失. 因此，即便模型选择正确，使式 2.24 中的均方误差最小通常也只会给定数据集 $\mathcal{D}$ 上表现良好，对先前未见数据点则未必如此. 原因是节 2.2 已介绍的过拟合：目标中的噪声被吸收到模型参数 $\boldsymbol{\theta}_{\text{MLE}}$ 中. 为解决这一问题，我们已引入正则化. 在线性模型式 2.23 中，可以通过贝叶斯推断实施正则化. 也就是说，不再只最大化式 2.26 的数据似然，还要在先验分布 $p(\boldsymbol{\theta})$ 中编码关于模型的先验知识. 根据式 2.19 的 Bayes 规则，可以计算给定数据集时参数的后验分布 $p(\boldsymbol{\theta} | \mathbf{X}, \mathbf{y})$ ²⁴，并转而最大化该量. 这得到最大后验估计 (maximum a posteriori estimate, MAP)：

$$\boldsymbol{\theta}_{\text{MAP}} := \arg \max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} | \mathbf{X}, \mathbf{y}) \quad (2.32)$$

$$= \arg \max_{\boldsymbol{\theta}} \frac{p(\boldsymbol{\theta})p(\mathbf{y} | \mathbf{X}, \boldsymbol{\theta})}{p(\mathbf{X}, \mathbf{y})}. \quad (2.33)$$

第二步使用了式 2.19. 分母不依赖 $\boldsymbol{\theta}$ ，故可忽略. 似然仍采用式 2.26 的假设. 作为先验，令参数值从以 $\mathbf{0}$ 为中心、方差为 τ^2 的高斯分布中抽取：

$$p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta} | \mathbf{0}, \tau^2 \mathbf{1}). \quad (2.34)$$

两个高斯分布的乘积仍为高斯分布，因而可以像式 2.29 那样使用对数技巧，得到

$$\begin{aligned} \boldsymbol{\theta}_{\text{MAP}} &= \arg \min_{\boldsymbol{\theta}} \left[\mathcal{L}_{\text{MSE}}(\boldsymbol{\theta} | \mathcal{D}) + \frac{\sigma^2}{\tau^2} \|\boldsymbol{\theta}\|^2 \right] \\ &= \left(\mathbf{X}^\top \mathbf{X} + \frac{\sigma^2}{\tau^2} \mathbf{1} \right)^{-1} \mathbf{X}^\top \mathbf{y}. \end{aligned} \quad (2.35)$$

²⁴之所以称为后验，是因为它在观测数据集 $\mathcal{D}$ 之后计算.

可以把 $\lambda = \sigma^2/\tau^2$ 看作信噪比；损失函数中的附加项有效惩罚幅度较大的参数值，因此 λ 称为正则化强度（regularization strength）。这种损失项称为Tikhonov 正则化（Tikhonov regularization），相应的最大后验估计量也称为线性岭回归（ridge regression）估计量。

比较式 2.25 与式 2.35 两个估计量。后者中的附加项 $\sigma^2\mathbf{1}/\tau^2$ 来自同时计及数据噪声与参数约束。在 $\tau \rightarrow \infty$ 的极限下，两者都被舍弃²⁵，并有 $\boldsymbol{\theta}_{\text{MAP}} \rightarrow \boldsymbol{\theta}_{\text{MLE}}$ 。

为计及训练数据中的底层噪声，必须约束线性模型。以这种方式处理过拟合通常称为正则化。

最后，式 2.34 中的先验绝非唯一选择。实际上，正则化思想及相应惩罚项种类繁多 [13]。一个简单变体是用 ℓ_1 范数代替 ℓ_2 范数，这可通过选择参数的 Laplace 分布作为先验实现。相应估计量由 LASSO 回归（least absolute shrinkage and selection operator regression）给出 [68]。因为 ℓ_1 范数会严厉惩罚即使很小的参数值，所以它偏好参数 $\boldsymbol{\theta}$ 的稀疏解。在某些任务中，这可用于从候选池中检测显著特征 [69]。

2.4.2 逻辑回归

上一小节讨论了线性回归问题。如下所示，这一讨论可以非常直接地推广到分类任务。

逻辑回归（logistic regression）的基本思想是调整线性模型，使其估计给定输入落入各候选类别的概率。

考虑两个类别 K_1 和 K_2 ，以及待分类输入 $\mathbf{x}$ 。引入类条件密度 $p(\mathbf{x} | K_i)$ 和相应的基准类别先验概率 $p(K_i)$ 。式 2.19 中的 Bayes 规则立即给出输入属于类别 K_1 的后验概率：

$$\begin{aligned} p(K_1 | \mathbf{x}) &= \frac{p(\mathbf{x} | K_1)p(K_1)}{p(\mathbf{x} | K_1)p(K_1) + p(\mathbf{x} | K_2)p(K_2)} \\ &= \frac{1}{1 + \exp(-\theta)} := \varsigma(\theta), \\ \text{其中 } \theta &:= -\log \left[\frac{p(\mathbf{x} | K_2)p(K_2)}{p(\mathbf{x} | K_1)p(K_1)} \right]. \end{aligned} \quad (2.36)$$

由此得到逻辑 sigmoid 函数（logistic sigmoid function） ς ，它把任意实值输入 θ 映射到区间 $[0, 1]$ 。现在可用线性模型（或任何其他机器学习模型）给出 θ 的值，再把它映射为相应后验概率。这一附加层把回归模型转化为分类器。

为了推广到两个以上的类别，可以作类似于式 2.36 的重新表述。此时得到 softmax 函数（softmax function）

$$p(K_k | \mathbf{x}) = \frac{\exp(\theta_k)}{\sum_i \exp(\theta_i)} := \text{softmax}(\boldsymbol{\theta}). \quad (2.37)$$

²⁵这对应参数 $\boldsymbol{\theta}$ 的均匀先验。




图 2.5: 二维问题中支持向量机的几何构造. (a) 紫色直线由 θ 完全描述, 是分离两类数据 (粉色点和绿色点) 的一个示例超平面. (b) 最优超平面使自身与支持点之间的间隔 M 最大; 支持点是最接近超平面的训练数据点.

它把输出得分向量 θ 一次性映射为所有类别上的正规概率分布. 其名称来自如下事实: 在 $\theta_i \gg \theta_k$ 对一切 $k \neq i$ 成立的极限下, softmax 收敛到最大值函数, 即 $\text{softmax} \rightarrow \max$.

在这两种情形中, 模型训练都先让输出得分通过式 2.36 或式 2.37, 再分别计算并最小化式 2.2 或式 2.3 中的损失. 任何分类器都值得关注的方面, 是它如何在两个不同类别的数据之间画出一条线; 这条线称为决策边界 (decision boundary). 线性模型的决策边界是线性的, 这是模型选择的直接结果. 由于特定损失函数使这条边界从数据似然导出, 模型极易受到离群点影响. 规避这一问题的一种方法, 是用几何方法寻找决策边界; 下一小节将采用这种做法.

2.4.3 支持向量机

除最大化模型似然外, 另一种分类方法是分析数据的几何性质. 这一思想体现在支持向量机 (support vector machine, SVM) 框架中, 其起源可追溯到 20 世纪 60 年代, 见文献 [70] 及其参考文献. 为直观展示数据几何, 考察图 2.5 中的线性可分问题. 在图 (a) 中, 为分类两类数据, 可以画一条分离训练数据的直线, 更一般地说是超平面. 此后无需对测试数据作概率预测, 只需检查测试点位于超平面的哪一侧. 图 (a) 还给出简单的几何分析: 分离数据的超平面方程为 $\theta^T x + \theta_0 = 0$. 垂直于超平面的单位向量为 $\theta^* = \theta / \|\theta\|$, 点 x 到超平面的最短距离为

$$d(x, \theta) = \frac{\theta^T x + \theta_0}{\|\theta\|}. \quad (2.38)$$

若不施加额外约束, 能够把数据分成两类的超平面有许多个. 应如何选择最佳者? 一种方法是使超平面与数据点之间的距离最大 [71]. 因此, 规定所有数据点到超平面的距离至少为 M . 与超平面距离恰为 M 、因而最接近它的数据点, 就是图 2.5(b) 中的支持点 (support points). 分类问题归结为寻找使间隔最大的 θ . 根据式 2.38, 可写成

$$y_i(\theta^T x_i + \theta_0) \geq M \|\theta\|. \quad (2.39)$$

观测向量的元素 y_i 取 ± 1 ，从而无论数据点属于哪个类别，上式总为正。若把 θ 的每个系数乘以同一因子，上述等式或不等式仍成立。因此可以任意重标度 θ 和 θ_0 ，令 $\|\theta\| = 1/M$ ，得到数据集中每个数据点都满足的规范条件

$$y_i(\theta^\top \mathbf{x}_i + \theta_0) \geq 1. \quad (2.40)$$

所以，为寻找最优超平面，需要在保证每个数据点都满足上述约束时，使 $\|\theta\|$ 最小。这是约束优化问题，可以使用 Lagrange 乘子。带约束地最小化 $\|\theta\|$ ，归结为最小化如下 Lagrange 函数 (Lagrange function)：

$$L = \frac{1}{2} \|\theta\|^2 - \sum_i^n \alpha_i [y_i(\theta^\top \mathbf{x}_i + \theta_0) - 1]. \quad (2.41)$$

其中 Lagrange 乘子 (Lagrange multipliers) α_i 选择为使

$$\alpha_i [y_i(\theta^\top \mathbf{x}_i + \theta_0) - 1] = 0, \quad \text{对每个 } i. \quad (2.42)$$

有趣的是，式 2.41 中的损失函数连同上述约束构成所谓二次规划 (quadratic program)：函数本身是二次的，而约束对 $\|\theta\|$ 是线性的。因而它有全局最小值，通常用序列最小优化 (sequential minimal optimization) [72] 求解，而不是使用任何迭代式梯度方法。

还应注意，式 2.42 对 Lagrange 乘子的条件意味着：

- 若 $\alpha_i > 0$ ，则 $y_i(\theta^\top \mathbf{x}_i + \theta_0) - 1 = 0$ ，即点 $\mathbf{x}_i$ 位于间隔带边界上。
- 若 $y_i(\theta^\top \mathbf{x}_i + \theta_0) - 1 > 0$ ，则该点位于间隔之外，并且 $\alpha_i = 0$ 。

因此，最终模型系数只由位于间隔带边界上的点 $\mathbf{x}_i := \mathbf{x}_{s,i}$ 给出。这些点就是支持点，支持向量机也由此得名。支持向量机问题随后依赖数值最小化 L ²⁶，从而求出只对支持点非零的系数 α_i 。

因此，用支持向量机分类，就是通过使超平面与支持点（即最接近决策边界的数据点）之间的间隔最大，找到分离数据的最优超平面。这个带约束的优化问题用 Lagrange 乘子求解，并且是凸的。

利用所求得的最优超平面 $\hat{f}$ ，可在任意测试点 $\mathbf{x}^*$ 作出预测：

$$\begin{aligned} \hat{f}(\mathbf{x}^*) &= \theta^\top \mathbf{x}^* + \theta_0 = \sum_i^n \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}^* + \theta_0 \\ &= \sum_i \alpha_i y_i \mathbf{x}_{s,i}^\top \mathbf{x}^* + \theta_0. \end{aligned} \quad (2.43)$$

最后一个求和只遍及支持点。要把该值转成类别预测，只需取 $\hat{f}$ 的符号作为相应类别标签。

²⁶实践中并非最小化 L ，而是最大化 Lagrange 对偶 L_D ，后者给出 L 的下界。节 4.2.2 将更详细地说明。

至此只考虑了线性可分数据集的二元分类问题. 把支持向量机推广到有 K 个类别的分类问题, 有两种显然的方法. 第一种称为一对一方法 (one-to-one approach), 把多类情形分解为每两个类别组合之间的独立二元分类; 随后需要训练 $\mathcal{O}(K^2)$ 个支持向量机才能预测. 第二种一对其余分类 (one-to-rest classification) 减轻了数值开销: 只需为 K 个类别各训练一个支持向量机, 判断测试点是否属于该类别. 另一种推广是不可线性分的分类问题, 节 4.2.2 将在后文说明.

2.4.4 神经网络

人工神经网络 (artificial neural network, ANN) (通常简称神经网络 (neural network, NN)) 是机器学习任务中用于处理数据的一大类模型. 它们是由许多简单函数复合而成的参数化函数. 顾名思义, 人工神经网络最初受到人脑神经网络的宽泛启发. 神经网络通常由相互连接的层组成, 各层依次处理信息, 见图 2.6. 每层包含多个节点或单元, 也称人工神经元 (artificial neuron) 或感知机 (perceptron).²⁷ 每个节点 i 接收向量 $\mathbf{x} = (x_1, x_2, \dots, x_m) \in \mathbb{R}^m$ 作为输入, 该向量对应前一层所有节点的激活值. 节点输出标量 $a_i \in \mathbb{R}$ (即它的激活值 (activation)), 其计算式为 $a_i = \varsigma(\sum_j w_{i,j}x_j + b_i)$. 参数 $\{w_{i,j}\}_{j=1}^m$ 和 $b_i \in \mathbb{R}$ 分别是节点 i 的权重与偏置. 节点权重控制它与前一层神经元之间连接的强度. ς 是称为激活函数 (activation function) 的非线性函数. 常见选择包括修正线性单元 (rectified linear unit, ReLU)

$$\varsigma(z) = \max(0, z), \quad (2.44)$$

逻辑 sigmoid 函数 (式 2.36), 以及 tanh 函数

$$\varsigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}. \quad (2.45)$$

第一层称为输入层 (input layer), 其节点的激活值根据编码输入数据的向量 $\mathbf{x}$ 设定. 最后一层称为输出层 (output layer), 其节点的激活值构成神经网络的输出. 所有中间层都称为隐藏层 (hidden layer). 默认情况下, 每个节点都与后一层全部节点相连的神经网络称为全连接 (fully connected) 神经网络. 神经网络的层数、节点数及其连接方式称为神经网络的架构 (architecture). 含有许多隐藏层的神经网络被认为是深层网络.²⁸ 以深度神经网络 (deep neural network, DNN) 为模型的机器学习方法统称为深度学习 [13].

关于神经网络, 一个核心问题是它们能够表示哪些类型的函数 (回顾此前关于传统机器学习与深度学习的讨论). 先考察去掉非线性激活函数的神经网络. 这种网络实现的函数只是简单的仿射映射 (affine map), 即以权重矩阵乘输入, 再加上一个偏置向量. 因此, 加入非线性激活函数对于神经网络表示更广泛的函数类别至关重要. 例如, Kolmogorov 和 Arnold [75] 证明, 任意连续高维函数都可以表示为一组非线性函数之复

²⁷ 此处及下文所说的是 Minsky 和 Papert [73] 提出的现代感知机; 它可以采用光滑激活函数, 这不同于 Rosenblatt 原始感知机 [74] 所用的 Heaviside 阶跃函数.

²⁸ 对于区分浅层与深层神经网络的深度阈值, 目前并无明确共识.




图 2.6: (a) 典型的全连接神经网络（此处为两层网络），以及 (b) 其中一个神经元（简单感知机）及其相应计算的示意图。

合的线性组合：

$$f(\mathbf{x}) = \sum_{i=0}^{2m} \zeta_i \left(\sum_{j=1}^m \varsigma_{i,j}(x_j) \right). \quad (2.46)$$

其中 ζ_i 和 $\varsigma_{i,j}$ 是分别作用于输入 $\mathbf{x} \in \mathbb{R}^m$ 各分量的非线性函数。这意味着，只用多项式数量 $O(m^2)$ 的一维非线性函数，就能表示任意函数 $f(\mathbf{x})$ 。这一结构与含两个隐藏层的神经网络非常相似。但要注意，必须根据目标函数谨慎选择这些非线性函数。在神经网络中，非线性函数通常固定为 $\zeta_i = \varsigma_{i,j}$ （对所有 i, j ）。事实表明，由单个隐藏层和非线性激活函数组成的全连接神经网络也是通用函数逼近器（universal function approximator）。换言之，只要目标函数性质足够良好，并且隐藏层含有足够多的节点，就能以任意期望精度逼近它 [76, 77, 13]。不过，所需隐藏层的规模仍可能随节点数呈指数增长。这便引出了具有多个隐藏层的神经网络能够实现什么的问题。

通用逼近定理（universal approximation theorem）保证存在某个神经网络，即存在某种网络架构以及权重和偏置的选择，能够任意精确地逼近给定目标函数。然而，它并不保证我们能够找到这一选择。实践表明，与浅层神经网络相比，深度神经网络往往能用少得多的节点，也就是少得多的可训练参数，解决许多问题。从这个意义上说，选择深度神经网络而非浅层神经网络，就在神经网络能够逼近的函数空间上引入了一个有用的先验。

神经网络的参数通常采用随机梯度下降或 Adam 等基于梯度的方法优化，以最小化给定损失函数 $\mathcal{L}$ （见节 2.1）。数值计算损失函数关于神经网络参数的梯度通常使用反向传播 [78]；节 2.5 将作更详细的讨论。相比之下，用给定输入求神经网络的输出时，信息沿网络向前流动，因此这一过程称为前向传播（forward propagation）。

卷积神经网络（convolutional neural network, CNN）是一类特殊的神经网络。与全连接神经网络不同，其中并非每个节点都与后一层的所有节点相连；后续层激活值的计算以卷积代替矩阵乘法。每层参数数量的减少使我们能够构建和训练更深的架构。此外，这种模型架构利用了输入数据通常具有的空间层级结构。对于图像类数据，空间上相近的像素一般比相距较远的像素具有更强的相关性。卷积神经网络用具有局部连接性的多个卷积层取代标准神经网络的全连接结构，从而利用了相关性随距离增大而消失这




图 2.7: 二维卷积层示意图: 固定大小 (此处为 3×3) 的核或滤波器与二维输入图像作卷积. 颜色强度对应神经元激活值以及核 (滤波器) 权重的大小.

一性质.

图 2.7 展示了卷积神经网络背后的工作原理——卷积: 让带有可训练权重的滤波器 (filter) (也称核 (kernel)) 在给定层上滑动. 随后, 将神经元激活值与滤波器权重逐元素相乘, 求取总和并应用非线性激活函数, 由此得到输出激活值. 这种滤波使神经网络只在局部相连, 而非全连接. 因此, 权重数不依赖输入大小, 而取决于滤波器大小. 滤波器大小控制输入数据中空间相关性被探测的范围. 输入数据自然表示为向量或矩阵时, 可以分别构建一维或二维卷积神经网络, 并采用相应维数的滤波器. 在典型卷积神经网络中, 经过若干卷积层后, 激活值被展平为单个特征向量. 这对应输入数据的一种低维表示, 随后再用全连接架构进一步处理. 为降低卷积层所得数据表示的维数, 通常还使用池化操作 (pooling operation). 池化把相邻滤波器应用所得的激活值组合起来, 例如取其最大值或平均值.

2.4.5 自动编码器

自动编码器 (autoencoder, AE) [79, 80] 是无监督学习中广泛使用的机器学习工具. 无标签数据 (例如图像、音频信号和文本) 往往是高维的, 因此直接在数据域中分析并提取模式十分困难. 而降维技术 (例如见节 3.2.1) 为从这类无标签数据中提取有用知识提供了一条有效途径. 简言之, 自动编码器的目标, 是把给定输入数据中的某些知识、模式和属性精确地编码 (encoding) 到低维流形上的某个潜变量 (latent variable)²⁹中. 借助所谓瓶颈 (bottleneck) 结构 (见图 2.8), 输入数据的潜在表示随后利用架构在特征提取 (编码) 阶段获取的信息, 被映射回输入空间, 这一过程称为解码 (decoding).

这种瓶颈架构以分别执行编码和解码的两个神经网络为基础. 训练这些神经网络时, 要最小化所谓重构损失 (reconstruction loss); 也就是说, 编码器-解码器对的最优设置, 应使输出 $\mathbf{x}_{\text{rec}}$ 的重构结果尽可能接近原始输入数据 $\mathbf{x}$. 两个神经网络通过迭代过程联合优化. 换言之, 对于一组可能的编码器和解码器, 我们要寻找这样一对: 编码时保留的信息最多, 解码时的重构误差最小.

这种联合优化迫使模型只保留重构输入所需的数据变化, 而不保留输入中的冗余.

²⁹潜变量是无法直接观测的随机变量. 此处称这些变量为潜变量, 是因为我们没有在数据中观测到它们.




图 2.8: 自动编码器瓶颈架构示例. 左侧的编码器神经网络把输入连接到瓶颈, 右侧的解码器神经网络则把瓶颈连接到输出.

因而与主成分分析类似, 学习过程只提炼描述数据的最相关特征. 一个重要事实是, 瓶颈是这种网络设计的关键属性; 如果没有信息瓶颈 (information bottleneck), 网络很容易学会把输入值原样沿网络传递, 从而只是记住它们. 此外, 由于采用一对神经网络, 自动编码器本质上比标准降维算法 (例如主成分分析) 更加灵活、表达能力也更强; 后者依赖通过受约束的线性或非线性变换, 把输入数据投影到子流形上.

自动编码器有多种类型和变体, 它们都以这一基本瓶颈性质作为基础结构. 在生成模型语境中, 自动编码器进一步发展的一个具体例子是变分自动编码器 (variational autoencoder, VAE). 顾名思义, 变分自动编码器 [79] 与变分推断 (variational inference) 有关. 实践中, 它们以稍微更复杂的方式训练编码-解码对. 编码部分从数据中提取的知识被嵌入一个基础概率密度中 (例如初始化为 Gaussian 分布), 再对该密度进行训练和调整, 使它成为底层数据分布的良好近似 (采样器). 训练完成后, 输入数据的潜在表示便成为一个概率密度; 可以从中采样与训练数据相似、具有相同已学习特征的全新未见数据. 因而此处的目标不再只是从提取的知识重构输入数据, 还要生成与训练集尽可能相似的新样本. 自动编码器的其他例子包括稀疏自动编码器 [81, 82]、去噪自动编码器 [83] 和重要性加权自动编码器 [84] 等.

2.4.6 自回归神经网络

作为本节的最后一种模型, 下面简要介绍自回归神经网络 (autoregressive neural network, ARNN). 这类网络最初受统计学与经济学中的自回归模型 (autoregressive model) 启发; 后者可用于预测时间序列 (例如某种金融资产) 的未来值. 自回归神经网络被形式化用于一般的密度估计任务 [85], 其目标是估计复杂的高维概率密度函数, 另




图 2.9: 循环神经网络示意图. 由于条件概率只依赖先前的输入数据, 可以直接看出该模型是自回归的. 蓝色方框表示正文所述的非线性变换. 此处任务是生成有意义的句子: 输入数据是一个句子, 输出则是在给定先前单词的条件下, 单词 W 成为句中下一个单词的概率. h_i 是隐藏向量, 用于计及先前循环神经网络变换所继承的记忆效应.

见节 7.2. 网络的输出被构造为满足如下条件结构:

$$f(\mathbf{x}) = \prod_{i=1}^m f_i(x_i | x_{i-1}, \dots, x_1). \quad (2.47)$$

其中 $\mathbf{x} = (x_1, x_2, \dots, x_m)$ 是模型输入. 对时间序列而言, 输入 x_i 是变量在时刻 t_i 的值, 模型 f 尝试根据过去的值预测未来值.

这类网络的一个一般例子, 是在自然语言处理任务中得到普及的循环神经网络 (recurrent neural network, RNN). 这类模型的核心思想是让信息回送到模型中, 从而在网络的不同部分之间引入相关性, 这与前馈网络不同. 粗略地说, 句子具有因果顺序, 但词语之间的相关性不一定在彼此相邻时最强. 因此, 引入带记忆的反馈回路, 在直觉上是可以理解的. 长短期记忆 (long short-term memory, LSTM) 在这一思想上引入长、短两种记忆时间尺度, 并且也已在此类任务中取得成功 [86].

图 2.9 以一个语言处理任务为用例, 勾画了循环神经网络的结构. 此处目标是根据先前单词预测句中的下一个单词. 这种网络的参数包含在循环神经网络单元中, 并参与如下非线性变换:

$$\mathbf{h}^{(i)} = \varsigma \left(\mathbf{W}_h \mathbf{h}^{(i-1)} + \mathbf{W}_x \mathbf{x}^{(i)} \right).$$

其中 $\mathbf{W}_h$ 和 $\mathbf{W}_x$ 是两个权重矩阵; $\mathbf{h}^{(i)}$ 是第 i 个隐藏向量, 表示来自先前单元的信息; $\mathbf{x}^{(i)}$ 是输入数据的第 i 个元素; ς 是逐元素作用的某个非线性激活函数.³⁰ 对于词语, $\mathbf{x}^{(i)}$ 表示以某种形式编码的句中第 i 个词, 例如采用独热编码. 这一变换存在若干变体, 其中最常用的是门控循环单元 (gated recurrent unit, GRU) [87].

³⁰ 还需选择初值 $\mathbf{x}^{(0)}$ 和 $\mathbf{h}^{(0)}$, 它们通常取零向量.

自回归模型已经用于物理学中的多类问题, 包括统计力学 [88, 89, 90]、量子层析 [91] 和基态搜索 [92]. 在章 5 与节 7.2 中, 我们将着重说明使用这类模型的优势, 并介绍它们在量子物理与量子化学中取得的突出成果.

2.5 反向传播

如节 2.1 所述, 神经网络通常用基于梯度的方法训练. 这些方法要求计算损失函数关于每个可训练参数的导数. 原则上, 给定特定神经网络架构, 可以推导梯度的闭式表达; 但架构改变后就必须重新推导. 这种计算还需要人工参与, 既繁琐又容易出错. 因此, 我们希望尽可能高效地自动完成梯度计算. 训练大型神经网络的首选算法是反向传播 [78]. 反向传播属于更大的一类自动微分算法; 它们能够高效、自动地求出由计算机程序表示之函数的导数. 节 7.1 将详细描述并比较这些方法.

反向传播的基本思想, 是利用神经网络由人工神经元等许多基本构件依次组成这一事实, 通过反复反向应用链式法则计算导数.

为建立直觉, 下面在一个简单前馈网络上说明反向传播; 其中每层节点只与紧随其后的下一层节点相连. 不过, 这一基本原理也适用于前文介绍的卷积神经网络、自动编码器和循环神经网络等其他架构. 回顾前馈神经网络第 l 层节点的激活值:

$$\mathbf{a}^{(l)} = \varsigma^{(l)}(\mathbf{z}^{(l)}) = \varsigma^{(l)}(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}). \quad (2.48)$$

其中 $\mathbf{a}^{(l-1)}$ 是包含前一层 (即第 $l-1$ 层) 激活值的向量. 相应权重矩阵为 $\mathbf{W}^{(l)}$, 其中 $w_{i,j}^{(l)}$ 是从第 $l-1$ 层节点 j 到第 l 层节点 i 的连接权重; $\mathbf{b}^{(l)}$ 是第 l 层偏置向量, $\varsigma^{(l)}$ 是第 l 层激活函数. 把多个这样的层堆叠起来, 便得到含 L 层 ($L-1$ 个隐藏层和一个输出层) 的前馈神经网络所实现的函数:

$$\mathbf{NN}(\mathbf{x}) = \mathbf{a}^{(L)}(\mathbf{x}) = \varsigma^{(L)}(\mathbf{W}^{(L)}\mathbf{a}^{(L-1)}(\mathbf{x}) + \mathbf{b}^{(L)}). \quad (2.49)$$

这里 $\mathbf{a}^{(0)}(\mathbf{x}) = \mathbf{x}$ 是输入向量. 关键观察是, 神经网络输出对输入 $\mathbf{x}$ 的依赖只通过前一层激活值 $\mathbf{a}^{(L-1)}$ 传递; 后者又只通过 $\mathbf{a}^{(L-2)}$ 依赖输入, 依此类推 (见式 2.48). 这是前馈神经网络逐层处理信息的直接结果.³¹

最终, 我们希望计算损失函数 $\mathcal{L}$ 关于所有权重的导数 $\partial\mathcal{L}/\partial w_{i,j}^{(l)}$, 以及关于所有偏置的导数 $\partial\mathcal{L}/\partial b_i^{(l)}$. 下文只讨论权重, 但步骤可直接推广到偏置. 对训练数据集 $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n$, 损失函数通常取平均值

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i). \quad (2.50)$$

其中 ℓ 衡量预测 $\mathbf{NN}(\mathbf{x}_i)$ 与相应期望输出 $\mathbf{y}_i$ 的偏差, 也可能含有额外正则化项. 因而

$$\frac{\partial\mathcal{L}}{\partial w} = \frac{1}{n} \sum_{i=1}^n \frac{\partial\ell(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i)}{\partial w}, \quad (2.51)$$

³¹事实上, 前馈网络可以推广到任意有向无环图. 无论如何, 信息处理都沿从输入节点到输出节点的前向方向进行.

其中 w 是神经网络的单个权重. 由式 2.51 可见, 主要任务归结为针对固定输入-输出对 $(\mathbf{x}_i, \mathbf{y}_i)$ 计算如下导数:

$$\begin{aligned}\frac{\partial \ell(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i)}{\partial w} &= \frac{\partial \ell(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i)}{\partial \mathbf{NN}} \cdot \frac{\partial \mathbf{NN}(\mathbf{x}_i)}{\partial w} \\ &= \frac{\partial \ell(\mathbf{a}^{(L)}(\mathbf{x}_i), \mathbf{y}_i)}{\partial \mathbf{a}^{(L)}} \cdot \frac{\partial \mathbf{a}^{(L)}(\mathbf{x}_i)}{\partial w}.\end{aligned}\quad (2.52)$$

对于给定损失函数, 第一个因子可以手工计算 (见节 2.1). 例如, 均方误差损失为

$$\ell_{\text{MSE}}(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i) = \|\mathbf{NN}(\mathbf{x}_i) - \mathbf{y}_i\|^2, \quad (2.53)$$

从而

$$\frac{\partial \ell_{\text{MSE}}(\mathbf{NN}(\mathbf{x}_i), \mathbf{y}_i)}{\partial \mathbf{NN}} = 2(\mathbf{NN}(\mathbf{x}_i) - \mathbf{y}_i). \quad (2.54)$$

所以核心待求量是

$$\frac{\partial \mathbf{NN}(\mathbf{x})}{\partial w} = \frac{\partial \mathbf{a}^{(L)}(\mathbf{x})}{\partial w}, \quad (2.55)$$

下面用链式法则的反复应用来计算它, 并省略对 $\mathbf{x}$ 的显式依赖.

反向传播算法的关键观察是: 由于前馈神经网络逐层处理信息, 第 l 层的权重只能通过下一层 $l+1$ 影响损失. 从最后一层 L 开始. 根据式 2.48, $\mathbf{a}^{(l)} = \varsigma^{(l)}(\mathbf{z}^{(l)})$. 使用链式法则得到

$$\begin{aligned}\frac{\partial \mathbf{a}^{(L)}}{\partial w} &= \frac{\partial \mathbf{a}^{(L)}}{\partial \mathbf{z}^{(L)}} \frac{\partial \mathbf{z}^{(L)}}{\partial w} \\ &= \frac{\partial \mathbf{a}^{(L)}}{\partial \mathbf{z}^{(L)}} \left(\frac{\partial \mathbf{W}^{(L)}}{\partial w} \mathbf{a}^{(L-1)} + \mathbf{W}^{(L)} \frac{\partial \mathbf{a}^{(L-1)}}{\partial w} \right).\end{aligned}\quad (2.56)$$

其中 $\partial \mathbf{a}^{(L)} / \partial \mathbf{z}^{(L)} = \mathbf{J}_{\varsigma}^{(L)}$ 是 $\varsigma^{(L)}$ 的 Jacobian 矩阵 (Jacobian matrix), 其元素为激活函数的导数 $(\mathbf{J}_{\varsigma}^{(L)})_{i,j} = \partial \varsigma_i^{(L)}(\mathbf{z}) / \partial z_j$. 注意, 对于 ReLU (式 2.44) 等函数, $\mathbf{J}_{\varsigma}^{(l)}$ 是对角矩阵; 对于 softmax 函数 (式 2.37) 则不是. 若 w 是第 L 层权重, 即 $w = w_{i,j}^{(L)}$, 则由式 2.56 有

$$\frac{\partial \mathbf{a}^{(L)}}{\partial w} = \mathbf{J}_{\varsigma}^{(L)} \mathbf{e}_i^{(L)} a_j^{(L-1)}. \quad (2.57)$$

这里 $\mathbf{e}_i^{(L)}$ 是第 L 层的激活向量: 除第 i 个节点的激活值为 1 外, 其余节点激活值均为 0. 若 w 不属于第 L 层, 则

$$\frac{\partial \mathbf{a}^{(L)}}{\partial w} = \mathbf{J}_{\varsigma}^{(L)} \mathbf{W}^{(L)} \frac{\partial \mathbf{a}^{(L-1)}}{\partial w}. \quad (2.58)$$

为求此式, 需要继续向前面的层回溯, 计算

$$\begin{aligned}\frac{\partial \mathbf{a}^{(L-1)}}{\partial w} &= \frac{\partial \mathbf{a}^{(L-1)}}{\partial \mathbf{z}^{(L-1)}} \frac{\partial \mathbf{z}^{(L-1)}}{\partial w} \\ &= \mathbf{J}_{\varsigma}^{(L-1)} \left(\frac{\partial \mathbf{W}^{(L-1)}}{\partial w} \mathbf{a}^{(L-2)} + \mathbf{W}^{(L-1)} \frac{\partial \mathbf{a}^{(L-2)}}{\partial w} \right).\end{aligned}\quad (2.59)$$

同样，若 w 属于第 $L-1$ 层，即 $w = w_{i,j}^{(L-1)}$ ，则

$$\frac{\partial \mathbf{a}^{(L-1)}}{\partial w} = \mathbf{J}_\zeta^{(L-1)} \mathbf{e}_i^{(L-1)} a_j^{(L-2)}. \quad (2.60)$$

否则

$$\frac{\partial \mathbf{a}^{(L-1)}}{\partial w} = \mathbf{J}_\zeta^{(L-1)} \mathbf{W}^{(L-1)} \frac{\partial \mathbf{a}^{(L-2)}}{\partial w}. \quad (2.61)$$

识别出计算的递归性质后，在 w 不属于第 l' 至第 l 层时，有

$$\frac{\partial \mathbf{a}^{(l)}}{\partial w} = \mathbf{J}_\zeta^{(l)} \mathbf{W}^{(l)} \mathbf{J}_\zeta^{(l-1)} \mathbf{W}^{(l-1)} \dots \mathbf{J}_\zeta^{(l'+1)} \mathbf{W}^{(l'+1)} \frac{\partial \mathbf{a}^{(l')}}{\partial w}. \quad (2.62)$$

若 w 属于第 l' 层，即 $w = w_{i,j}^{(l')}$ ，则改为

$$\frac{\partial \mathbf{a}^{(l)}}{\partial w} = \mathbf{J}_\zeta^{(l)} \mathbf{W}^{(l)} \mathbf{J}_\zeta^{(l-1)} \mathbf{W}^{(l-1)} \dots \mathbf{J}_\zeta^{(l'+1)} \mathbf{W}^{(l'+1)} \mathbf{J}_\zeta^{(l')} \mathbf{e}_i^{(l')} a_j^{(l'-1)}. \quad (2.63)$$

至此已有构造反向传播算法所需的全部要素。回顾我们的目标，是计算式 2.52 中关于全部可调权重的导数。为高效完成计算，先在输出层初始化如下“偏差”：

$$\Delta^{(L)} = \frac{\partial \ell(\mathbf{a}^{(L)}(\mathbf{x}_i), \mathbf{y}_i)}{\partial \mathbf{a}^{(L)}} \odot \mathbf{J}_\zeta^{(L)}, \quad (2.64)$$

其中 $\odot$ 表示逐元素的 Hadamard 积 (Hadamard product)³²。这个中间量在整个计算中都很有用。以均方误差损失为例，根据式 2.54 有

$$\Delta^{(L)} = 2(\mathbf{a}^{(L)} - \mathbf{y}_i) \odot \mathbf{J}_\zeta^{(L)}. \quad (2.65)$$

由式 2.57，损失函数关于第 L 层权重 $w_{i,j}^{(L)}$ 的导数贡献为

$$2(\mathbf{a}^{(L)} - \mathbf{y}_i) \odot \mathbf{J}_\zeta^{(L)} \mathbf{e}_i^{(L)} a_j^{(L-1)} = \Delta^{(L)} \mathbf{e}_i^{(L)} a_j^{(L-1)}. \quad (2.66)$$

最终导数 $\partial \ell(\mathbf{a}^{(L)}(\mathbf{x}_i), \mathbf{y}_i) / \partial w_{i,j}^{(L)}$ 由该向量所有分量求和得到：

$$\frac{\partial \ell(\mathbf{a}^{(L)}(\mathbf{x}_i), \mathbf{y}_i)}{\partial w_{i,j}^{(L)}} = \sum_k \left(\Delta^{(L)} \mathbf{e}_i^{(L)} a_j^{(L-1)} \right)_k. \quad (2.67)$$

这正是式 2.52 内积中所有单项贡献之和。计算完关于第 L 层全部权重的导数后，向前回退一层，这也解释了“反向”传播之名。根据式 2.58，第 $L-1$ 层权重 $w_{i,j}^{(L-1)}$ 的导数贡献为

$$\Delta^{(L-1)} \mathbf{e}_i^{(L-1)} a_j^{(L-2)}, \quad (2.68)$$

其中

$$\Delta^{(L-1)} = \Delta^{(L)} \mathbf{W}^{(L)} \mathbf{J}_\zeta^{(L-1)}. \quad (2.69)$$

³² 只有一个输出节点时，它简化为通常的标量乘积。

注意，上述步骤与式 2.62、式 2.63 密切对应。递归地有

$$\Delta^{(l-1)} = \Delta^{(l)} \mathbf{W}^{(l)} \mathbf{J}_{\zeta}^{(l-1)}. \quad (2.70)$$

重复这一过程直到第一层。完成沿神经网络的反向遍历后，就得到式 2.52 中关于所有可调权重的目标导数。反向传播期间，必须知道全部激活值 $\{\mathbf{a}^{(l)}(\mathbf{x}_i)\}_{l=0}^L$ ，以及在相应激活值处求得的激活函数导数 $\{\mathbf{J}_{\zeta}^{(l)}(\mathbf{x}_i)\}_{l=1}^L$ 。为避免重复计算，执行反向传播算法（反向遍历）前，先在给定输入 $\mathbf{x}_i$ 上求值网络（前向遍历），并缓存所需的全部中间计算结果。

为进一步展示反向传播，考虑一个以均方误差为损失函数、以 ReLU 为激活函数的简单两层神经网络，并显式计算其前向和反向遍历。ReLU 逐元素作用， $\zeta^{(l)}(z) = \zeta(z) = \text{ReLU}(z) = \max(0, z)$ ；其导数在 $z > 0$ 时为 1，否则为 0。³³ 随机初始化网络权重并忽略偏置，见图 2.10(a)。示例输入-输出对的前向遍历见图 2.10(b)，其中缓存了所有中间结果，包括全部节点的激活值 $\mathbf{a}^{(1)}$ 、 $\mathbf{a}^{(2)}$ 及相应激活函数的导数。

随后从图 2.10(c) 开始反向遍历。此处只计算损失 ℓ 关于来自不同层的两个权重 $w_1^{(2)}$ 和 $w_{1,2}^{(1)}$ 的导数。第一步，根据式 2.65 计算末层偏差 $\Delta^{(2)}$ ，然后即可从内存删除 $\mathbf{a}^{(2)}$ 。接着根据式 2.66 计算 ℓ 关于末层任意权重 $\mathbf{w}^{(2)}$ 的导数，并可丢弃激活值 $\mathbf{a}^{(1)}$ 。下一步，根据式 2.70 计算倒数第二层的偏差 $\Delta_1^{(1)}$ 和 $\Delta_2^{(1)}$ ，此后可丢弃 $\Delta^{(2)}$ 。最后，用 $\Delta_1^{(1)}$ 、 $\mathbf{a}_2^{(0)} = x_2$ 和式 2.68 计算 $\partial \ell / \partial w_{1,2}^{(1)}$ 。对两层网络而言，至此梯度计算结束。注意，每一步都可以删除前向遍历的已用缓存结果，从而释放内存。

此时自然会问：为何反向而不是正向计算导数？为回答这一问题，先构造相应的“正向传播算法”。对希望计算式 2.52 中导数的每个权重 $w_{i,j}^{(l)}$ ，先计算


$$\frac{\partial \mathbf{a}^{(l)}}{\partial w_{j,i}^{(l)}} = \mathbf{J}_{\zeta}^{(l)} \mathbf{e}_i^{(l)} a_j^{(l-1)}. \quad (2.71)$$

再直接利用式 2.62 得到 $\partial \mathbf{a}^{(L)} / \partial w_{i,j}^{(l)}$ ，继而由式 2.52 计算最终导数。反向传播与正向传播算法的区别，分别相当于从左到右（反向）或从右到左（正向）求值式 2.63 中的表达式。


正向传播算法同样需要知道激活值与激活函数的导数，但无需缓存任何结果；导数计算可以与前向遍历（即神经网络求值）并行进行，因为信息逐层向前流动，后续阶段不显式需要更早层的信息。除内存成本不同外，正向传播与反向传播还有两个关键区别。第一，正向传播要重复计算后面各层的导数，存在大量冗余；反向传播没有这种冗余。第二，正向传播会进行不必要的中间计算，即求出各个节点的导数。最终结果是：正向传播算法遍历神经网络的次数随可调权重数增长，而反向传播并非如此。因而在计算神经网络梯度时，尤其对于含有大量可调参数的深度神经网络，通常优先使用反向传播。反向传播对深度学习的成功发挥了关键作用，并使神经网络得到广泛应用。关于这些概念及实现细节的更一般、深入讨论，见节 7.1。

³³严格说来，ReLU 在 $z = 0$ 处不可微。数值实践中通常把该处导数置为 0。

(a) two-layer NN with ReLUs and MSE loss



(b) forward pass for $(x,y) = ([1,1,0], 0)$ caching intermediate results



(c) backward pass for $(x,y) = ([1,1,0], 0)$ to compute gradients taking advantage of cached results from the forward pass




图 2.10: 简单两层前馈神经网络上的反向传播示例. (a) 网络结构; (b) 沿网络的前向遍历; (c) 计算导数的反向遍历.

延伸阅读

1. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer “Information Science and Statistics” 丛书. 标准机器学习的经典教材 [93].
2. Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press. 最优秀的深度学习教材之一，并讲解了全部预备知识 [13].
3. Mehta, P. *et al.* (2019). *A high-bias, low-variance introduction to machine learning for physicists*. *Phys. Rep.* 810, 1–124. 面向物理学家的机器学习入门 [94].
4. Zhang, A. *et al.* (2021). *Dive into Deep Learning*. 包含代码、数学与讨论的交互式深度学习图书，提供 NumPy/MXNet、PyTorch 和 TensorFlow 实现 [95].
5. Florian Marquardt 于 2020/21 年讲授的“面向物理学家的机器学习”课程录像，以及于 2021/22 年讲授的“面向物理、科学与人工科学发现的高级机器学习”课程录像.
6. 专门面向 STEM 学生开发的机器学习入门课程: [ML-lectures.org](https://ml-lectures.org), 以及配套内容 Neupert, T. *et al.* (2021). *Introduction to machine learning for the sciences*. arXiv:2102.04883 [96].
7. Carrasquilla, J. & Torlai, G. (2021). *How to use neural networks to investigate quantum many-body physics*. *PRX Quantum* 2, 040201. 附有代码、面向若干物理问题的机器学习教程 [97].

相分类

物理学中，机器学习、尤其神经网络可能格外有用的领域之一是凝聚态物理 [5]，它以研究相互作用粒子的集体行为为核心。描述这类系统的困难在于，粒子数增加时，自由度的数量迅速增长，导致构型空间随之扩大。绕开这些困难的“标准”方法，是寻找适当的序参量（order parameter）：它们无需追踪全部微观细节，就能表示系统中重要的“宏观”自由度。由序参量量化的有序程度自然地把物质区分为不同状态，即不同的相 [98, 99]。对某些系统，序参量十分简单：例如在铁磁体中，序参量就是磁化强度（magnetization），它由局域磁矩之和给出。然而一般而言，辨识序参量并把物质划分为不同相，都是困难的任务。例如，物质的拓扑相由本质上非局域的拓扑性质刻画。辨识序参量是理解多体系统底层物理的关键第一步；而为新的物质相找到恰当序参量，通常需要大量物理直觉和有根据的猜测。

另一方面，在计算机视觉等领域，人们已经证明可以训练神经网络，使其正确分类自然存在于高维空间中的复杂带标签数据集（例如 MNIST [31] 或 CIFAR [33]）。这促使我们探索机器学习技术，把它作为探查相关多体系统庞大状态空间的新工具；其他算法目前尚无法处理这些系统 [6]。在机器学习应用于凝聚态物理的所有潜在方向中，从（模拟或实验）数据学习物质相尤其引人入胜：它可能让我们在没有人类先验知识或监督的情况下发现新相与新物理。下面将向读者初步介绍利用机器学习进行相分类（phase classification）这一领域。

3.1 研究物质相的原型物理系统

下面简要介绍两个原型物理系统，后续各节将以它们展示相分类任务：一是 Ising 模型 [100]，它发生对称性破缺相变（symmetry-breaking phase transition），并可由简单的局域序参量刻画；二是 Ising 规范理论（Ising gauge theory, IGT）[101]，它不存在局域序参量的拓扑相。¹

3.1.1 Ising 模型

我们考虑二维方格晶格上的铁磁 Ising 模型（ferromagnetic Ising model）。它是发生相变的最简单经典统计模型之一，也为铁磁性提供了一种简单描述。当一组自旋取向一致，产生宏观尺度的净磁矩时，便会出现铁磁性。在 Ising 模型中，每个晶格格点 k 上都有一个离散的（经典）自旋变量 $\sigma_k \in \{+1, -1\}$ ；若有 N 个晶格格点，状态空间大

¹在 Landau 相变范式 [102, 103] 中，物质相之间的变化从根本上与底层对称性的变化相联系。值得注意的是，Landau 的对称性破缺相变理论不适用于物质的拓扑相 [104]。




图 3.1: (a) $J = 1, k_B = 1$ 时 Ising 模型在不同温度下的自旋构型样本, 其中 $T_c \approx 2.27$ (见式 3.5). 每个晶格格点上的蓝色 (橙色) 圆点表示该处自旋变量取值 $\sigma_k = 1$ ($\sigma_k = -1$). 该分图转载自文献 [2, Notebook A1]. (b) Ising 模型的每格点平均磁化强度 $\langle m(\sigma) \rangle_T$ 随温度 T 的变化.

小就是 2^N . 一个自旋构型的能量由如下 Hamiltonian 指定:

$$H(\sigma) = -J \sum_{\langle i, j \rangle} \sigma_i \sigma_j. \quad (3.1)$$

求和遍历所有最近邻格点 (采用周期性边界条件), J 是相互作用强度, 并且 $J > 0$ (铁磁相互作用).² 假定系统在逆温度 $\beta = 1/(k_B T)$ 下处于平衡, 其中 k_B 是 Boltzmann 常数, T 是温度. 此时, 在系统发现自旋构型为 σ 的状态, 其概率由 Boltzmann 分布 (Boltzmann distribution) 描述:

$$P_T(\sigma) = \frac{e^{-\beta H(\sigma)}}{Z_T}. \quad (3.2)$$

这里 $Z_T = \sum_{\sigma} e^{-\beta H(\sigma)}$ 是配分函数 (partition function), 求和遍历所有可能的自旋构型. Ising 模型在不同温度下的自旋构型样本见图 3.1(a). 利用式 3.2, 给定可观测量 $O(\sigma)$ 的期望值可写为

$$\langle O(\sigma) \rangle_T = \sum_{\sigma} P_T(\sigma) O(\sigma). \quad (3.3)$$

例如, 每格点磁化强度对应的可观测量为

$$m(\sigma) = \frac{1}{N} \sum_i \sigma_i. \quad (3.4)$$

1944 年, Onsager [100] 得到了如下临界温度解析表达式:

$$T_c = \frac{2J}{k_B \ln(1 + \sqrt{2})}. \quad (3.5)$$

² $J < 0$ 对应二维方格晶格反铁磁 Ising 模型; 它在同一临界温度发生相变.




图 3.2: 上排分图给出 Ising 规范理论在 $T = 0$ (左) 和 $T \rightarrow \infty$ (右) 时的自旋构型样本; 此时分别有所有元格和部分元格满足局域约束. 图中以红色标出一个示例元格. 下排分图给出相应的对偶表示, 其中星号突出标示环路断裂. 转载自文献 [2, Notebook A1].

在该温度处, 高温顺磁 (无序) 相与低温铁磁 (有序) 相之间发生相变, 见图 3.1. 温度低于临界温度 T_c 时, 会出现自发磁化: 相互作用足够强, 使相邻自旋自发取向一致, 从而产生非零平均磁化强度. 温度高于 T_c 时, 热涨落完全压倒一切自旋排列, 观测到的磁化强度为零. 因此, 磁化强度可以充当序参量: 它在无序 (顺磁) 相中为零, 在有序 (铁磁) 相中趋近于一, 见图 3.1(b).

3.1.2 Ising 规范理论

最令人振奋的研究方向之一, 是分类那些没有局域序参量、却具有全局序参量的相. 能带拓扑绝缘体和拓扑超导体就是具有这类相的系统实例 [105]. 从实验角度看, 探测拓扑相是一项困难任务, 因为实验人员通常只能接触局域可观测量. 在这一背景下, 机器学习技术可以提供很大帮助 [106, 107, 108, 109, 110, 111, 112].

Ising 规范理论 [101] 是具有物质拓扑相的原型系统. 与 Ising 模型一样, 它也是定义在方格晶格 (采用周期性边界条件) 上的经典自旋模型, $\sigma_k \in \{+1, -1\}$. 不过, 这里

的自旋位于晶格键上. 该理论由如下 Hamiltonian 描述:

$$H(\sigma) = -J \sum_p \prod_{i \in p} \sigma_i. \quad (3.6)$$

其中 p 表示晶格上的元格 (plaquette), 见图 3.2. 这个 Hamiltonian 的基态是一个高度简并的流形, 由所有满足如下局域约束的状态张成: 沿每个元格的自旋乘积均为 $\prod_{i \in p} \sigma_i = 1$. 因而, 这一基态对应物质的一个拓扑相. 在有限尺寸系统中, 局域约束的违反受到强烈抑制; 系统从低温拓扑相缓慢过渡到局域约束遭到违反的高温相. 据此可以定义交叉温度 T_c , 即第一次出现局域约束违反时的温度.³

有一种有趣的表示能够凸显 Ising 规范理论基态的拓扑特征: 连接自旋取向相同的晶格边, 使之形成环路. 于是, 基态相由所有这些环路均闭合这一性质刻画; 一旦违反某个约束, 就会出现开环, 见图 3.2. 观察 Ising 规范理论的典型自旋构型样本可以清楚看出, 如果事先不知道局域约束或相应的对偶表示, 就很难从视觉上区分其各个相. 因此, Ising 规范理论以及其他由非局域、长程关联刻画系统, 对任何相分类算法都构成了一项困难任务.

3.2 无神经网络的无监督相分类

介绍 Ising 模型和 Ising 规范理论之后, 下面讨论如何分类它们各自的物质相. 我们尤其关注无监督机器学习算法. 这类算法处理无需标签的训练数据 (见节 1.5), 必须自行发现训练数据集中的相关模式. 因此, 它们是自主发现新相的首要候选方法, 因为样本无须事先按照所属相加以标注.

这里尤其讨论执行降维 (dimensionality reduction) 的算法. 降维旨在把输入数据投影到较低维空间. 任何降维都必然造成信息损失, 但目标是只丢弃输入数据中与当前问题关系较小的信息. 人们尤其相信, 现实数据往往位于原空间内的低维流形上 [113]. 例如, 希望分类的图像集合通常只占所有可能图像空间的一个小子空间; 此时可以用较少自由度有效描述数据. 显然, 这种方法自然适合区分不同物质相并探测凝聚态系统中的相变: 我们希望舍弃信息丰富却复杂的系统微观描述, 换取更简单的宏观描述, 例如序参量.

完成降维后, 把数据在低维表示空间 (representation space) 中可视化, 或许已经能让我们了解给定问题的许多性质. 我们倾向于认为, 同一物质相的样本彼此之间应比它们与另一相的样本更相似. 如果降维方法保留了这种相似性的一部分, 数据可视化中应当能够显现出来. 然而, 这一点一般并无保证; 下面就会看到一个失败实例.

除可视化外, 还可用聚类 (clustering) 等方法进一步处理数据. 聚类是最基本的无监督学习方法之一, 它根据距离度量评估相似性, 把无标签数据归入由相似数据点组成的簇. 在此语境下, 各簇理想地对应数据中存在的不同物质相. 适用于不同数据类型的聚类算法有很多, k 均值聚类是最简单的算法之一 (更多细节见文献 [94]).

原则上, 聚类不一定要把降维作为预处理步骤. 不过, 降维可以从若干方面提供帮

³注意, 随着系统尺寸增大, $T_c \rightarrow 0$; 也就是说, 交叉温度在热力学极限下消失. 因而, Ising 规范理论不会在非零温度发生相变.

助 [114, 94]. 首先, 聚类通常依赖 Euclidean 距离能够良好度量相似性这一点.⁴ 然而, 原始高维表示中的数据往往被认为位于非 Euclidean 流形上, 因此其中两点间的距离可能并没有多大意义. 降维技术可以找出数据的低维 Euclidean 表示; 这一表示中数据点之间的 Euclidean 距离通常更有物理意义, 因而能改善聚类. 其次, 把降维作为预处理有助于缓解在高维空间中聚类时遇到的维数灾难 (curse of dimensionality). 最后, 找出低维表示也有助于更好地可视化并理解最终得到的聚类.

3.2.1 主成分分析

作为例子, 考虑常用的降维方法主成分分析 (PCA). PCA 在数据空间中找出一组彼此正交、且数据沿其线性相关性消失的方向, 这些方向称为主成分 (principal component, PC). 各主成分按照数据沿相应方向的方差排序. 为降低空间维数, 舍弃数据方差最小的那些主成分. 因此, PCA 把数据具有大方差的方向视为包含最重要的信息. 在当前问题中, 理想情形是: 把数据 (原始自旋构型样本) 显示在其低维表示中时, 它会自然分成与系统各个相对应的不同簇.

更确切地说, 设有 n 个数据点 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$, 每个点都位于 m 维特征空间 $\mathbb{R}^m$, 且均值为零, 即 $\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = 0$. 现实数据通常并非零均值, 此时首先需要逐元素减去均值来变换数据. 定义 $n \times m$ 设计矩阵 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]^T$. 对称的 $m \times m$ 经验协方差矩阵 (empirical covariance matrix) 为 $\Sigma = \frac{1}{n} \mathbf{X}^T \mathbf{X}$. 协方差矩阵的第 i 个对角元 Σ_{ii} 对应整个数据中第 i 个特征的方差, 非对角元 Σ_{ij} 则对应特征 i 与特征 j 的协方差. 特征之间相关性消失的基, 就是 Σ 呈对角形式的特征基. 因而, 寻找数据线性相关性消失的方向归结为对角化 Σ , 也就是求出其特征向量 (或主成分) $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m\}$ 和特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_m\}$. 特征值 λ_i 对应数据沿 $\mathbf{v}_i$ 方向的方差. 记第 j 个主成分包含的解释方差比 (explained variance ratio) 为 $\tilde{\lambda}_j = \lambda_j / \sum_{i=1}^m \lambda_i$. 该过程的数学推导见附录. 随后选择解释方差比最大的前 k 个主成分, 把数据投影到这一低维空间, 从而实现降维. 投影由线性变换 $\tilde{\mathbf{X}} = \mathbf{X} \tilde{\mathbf{V}}$ 完成, 其中 $\tilde{\mathbf{V}} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k]$, $\tilde{\mathbf{X}}$ 是投影后的设计矩阵. 需要选择保留的主成分数 k . 可以依具体问题临时决定, 也可以例如选择满足 $\sum_{i=1}^k \tilde{\lambda}_i \geq \tilde{\lambda}_{\text{thresh}}$ 的最小主成分数, 其中 $\tilde{\lambda}_{\text{thresh}}$ 是期望的解释方差比阈值.

算法 2 概括了这一过程. 为直观理解该过程, 可参见图 3.3(a)、(b): 此例中的数据位于二维特征空间. 减去数据均值后, PCA 找到包含最大比例数据方差的第一主成分. PCA 不仅可以理解为使方差最大, 也可以理解为使线性变换的重构误差最小. 两者等价性的证明见 Appendix A. 更多细节例如见文献 [94].

⁴一般而言, 无论选取的是 Euclidean 距离还是其他距离, 聚类能否成功都取决于所选距离度量是否能够良好衡量相似性.




图 3.3: (a) 对二维特征空间中的数据点（蓝色）应用 PCA 的原理示意图. 橙色向量表示前两个主成分，数据被投影到它们之上（右图）。取 $k = 2$ ，分别对 (b) Ising 模型和 (c) Ising 规范理论的自旋构型样本应用 PCA. 对 Ising 模型，数据由 50 个自旋构型组成（晶格线性尺寸 $L = 30$ ）；它们通过 Monte Carlo 方法，在温度从 $T_1 = 1$ 到 $T_{20} = 3.5$ 的 20 个等距取值处采样. 对 Ising 规范理论，数据由 1000 个自旋构型组成（晶格线性尺寸 $L = 16$ ），分别取自拓扑相和高温无序相. 分图 (b)、(c) 转载自文献 [2, Notebook A1].

算法 2 主成分分析 (PCA)

输入：超参数 k （投影后数据的维数）

输入：设计矩阵 $\mathbf{X} \in \mathbb{R}^{n \times m}$

$$\mathbf{X} \leftarrow \mathbf{X} - \text{mean}(\mathbf{X})$$

▷ 逐元素去除均值

$$\Sigma \leftarrow \mathbf{X}^\top \mathbf{X} / n$$

▷ 构造经验协方差矩阵

$$\mathbf{V} \leftarrow \text{Eigenvectors}(\Sigma)$$

▷ 求特征向量并按特征值降序排列

$$\tilde{\mathbf{V}} \leftarrow \mathbf{V}[:, :k]$$

▷ 只保留前 k 个特征向量

$$\text{返回 } \tilde{\mathbf{X}} \leftarrow \mathbf{X} \tilde{\mathbf{V}} \in \mathbb{R}^{n \times k}$$

现在可以直接对自旋构型样本应用 PCA. 图 3.3(b)、(c) 分别给出了对 Ising 模型和 Ising 规范理论自旋构型样本应用 PCA 的结果. 对 Ising 模型，PCA 把数据分为三个簇：一个对应无序相的高温簇，以及两个对应正、负磁化强度有序相的低温簇. 进一步分析表明，第一主成分对应磁化强度 [114]. 画出一条与第一主成分垂直、分隔高温簇和一个低温簇的竖直决策边界，可以粗略估计临界相变温度为 $T_{c, \text{PCA}} \approx 2.3$ ，与 Onsager 解一致. 对 Ising 规范理论，PCA 无法把数据聚成已有的两个相，见图 3.3(c). 这是因为 PCA 只允许对输入数据作线性变换. 线性变换足以编码简单的局域序参量 [114, 115, 116]，例

如 Ising 模型的磁化强度，却不足以计算拓扑特征，也就是数据中的非局域关联 [116].

Ising 规范理论上的失败表明，PCA 仅限于输入空间的线性变换，严重限制了它的性能。换言之，用 PCA 降维时，未必能找到最佳方向集合。特别是，数据在原空间中所在的低维流形，不一定能由原坐标的线性变换参数化。在这种情况下，PCA 降维无法保持数据点相对于流形的两两相对距离，即相似性；而任何降维算法都希望具有这一性质。非线性降维技术旨在解决这个问题，例如核 PCA (kPCA) [117] (核技巧见章 4)、t 分布随机邻域嵌入 (t-distributed stochastic neighbor embedding, t-SNE) [118] 和统一流形逼近与投影 (uniform manifold approximation and projection, UMAP) [119]。下一小节简要介绍 t-SNE。

3.2.2 t 分布随机邻域嵌入

随机邻域嵌入 (stochastic neighbor embedding, SNE) [120] 及其变体 t-SNE [118] 都是非线性降维技术，目标是保持原数据的局域结构。也就是说，高维数据集中彼此接近的点，在低维表示中也倾向于彼此接近。

算法 3 t 分布随机邻域嵌入 (t-SNE)

输入： 超参数： d (投影后数据的维数)、困惑度 P 、学习率 η

输入： m 维空间中由 n 个点组成的原数据集 $\mathbf{X} \in \mathbb{R}^{n \times m}$

输入： 较低维 $d_{\text{red}} < m$ 表示中的 n 个随机点 $\mathbf{Y}^{(0)} \in \mathbb{R}^{n \times d_{\text{red}}}$

```

for 每个  $x_i$  do
  for 每个  $x_j$  do
    以固定困惑度  $P$  计算两两条件概率分布  $p_{i|j}$ 
  end for
end for
计算概率分布  $p_{ij}$ 
for  $t = 1$  到  $T$  do
  for 每个  $y_i^{(t-1)} \in \mathbf{Y}^{(t-1)}$  do
    for 每个  $y_j^{(t-1)} \in \mathbf{Y}^{(t-1)}$  do
      计算概率分布  $q_{ij}$ 
    end for
    计算 KL 散度关于每个  $y_i^{(t-1)}(z_1^{(i)}, z_2^{(i)}, \dots, z_{d_{\text{red}}}^{(i)}) \in \mathbf{Y}^{(t-1)}$  坐标的梯度，即  $\partial D_{\text{KL}}(p||q)/\partial z^{(i)}$ 
  end for
   $\mathbf{Y}^{(t)} \leftarrow \mathbf{Y}^{(t-1)} - \eta \frac{\partial D_{\text{KL}}(p||q)}{\partial \mathbf{z}}$  ▷ 更新各点坐标
end for

```

考虑一个含 n 个点的初始 m 维空间，即 $\mathbf{x}_i \in \mathbb{R}^m$ 。定义两个点 $\mathbf{x}_i$ 、 $\mathbf{x}_j$ 相似（即彼此接近）的条件概率 $p_{i|j}$ 为

$$p_{i|j} = \frac{e^{-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / (2\sigma_i^2)}}{\sum_{k \neq i} e^{-\|\mathbf{x}_k - \mathbf{x}_i\|^2 / (2\sigma_i^2)}}. \quad (3.7)$$

其中 $\|\mathbf{x}_i - \mathbf{x}_j\|$ 是两点之间的 Euclidean 距离. $p_{i|j}$ 采用 Gaussian 似然, 意味着只有 $\mathbf{x}_i$ 附近的点才会对其概率作出显著贡献. 方差 σ_i^2 依赖如下定义的困惑度 (perplexity):

$$P_i = 2^{-\sum_{j=1}^n p_{j|i} \log_2 p_{j|i}}. \quad (3.8)$$

它是一种基于 Shannon 熵的度量. t-SNE 算法的第一步, 是分别优化各点 $\mathbf{x}_i$ 的方差 σ_i^2 , 使困惑度取固定值 $P_i = \text{const.}$ 高密度区域中的点具有较小方差, 低密度区域中的点具有较大方差. 实践中, 困惑度通常设在 5 到 50 之间. 注意, 由于 σ_i^2 的依赖关系, $p_{i|j} \neq p_{j|i}$. 为恢复对称关系, 定义联合概率分布

$$p_{ij} = \frac{p_{i|j} + p_{j|i}}{2n}. \quad (3.9)$$

t-SNE 算法的目标, 是在较低维表示中找出另一组点 $\mathbf{y}_i \in \mathbb{R}^{n \times d_{\text{red}}}$, 其中 $d_{\text{red}} < m$, 以及新表示中相应的概率分布 q_{ij} , 使 KL 散度

$$D_{\text{KL}}(p||q) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{q_{ij}} \quad (3.10)$$

最小.

该过程从在 d_{red} 维空间中随机抽取 n 个点 $\mathbf{y}_i(z_1, z_2, \dots, z_{d_{\text{red}}})$ 开始. 对每个点, 以与高维空间中类似的方式定义概率分布 q_{ij} , 但用 Student t 分布代替 Gaussian 分布:

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}}. \quad (3.11)$$

最后, 使式 3.10 中的 Kullback–Leibler (KL) 散度最小 (见节 2.3): 优化 d_{red} 维空间中每个点 $\mathbf{y}_i = \mathbf{y}_i(z_1, z_2, \dots, z_{d_{\text{red}}})$ 的位置 $(z_1, z_2, \dots, z_{d_{\text{red}}})$, 最终得到低维数据表示. 算法 3 概括了 t-SNE 算法.

低维数据表示保留了原数据集的局域结构, 即原数据集中相似的点现在会在 d_{red} 维表示空间中聚成簇. 然而, 在表示空间中, 所得各簇之间的距离不再具有意义.

一般而言, 把聚类与降维结合起来, 能够优雅地处理 Ising 模型等简单问题. 然而, 对更困难的相分类任务, 这类方法通常表现不佳; 例如系统具有 Ising 规范理论中的拓扑相 [121], 或者存在大量物质相 [122] 时, 都会出现这种情形.

3.3 利用神经网络进行监督相分类

人们或许会问, 上一节介绍的聚类方法所遇到的问题, 能否借助节 2.4.4 介绍的强大神经网络工具来解决. 基本思路如下 [123]: 训练神经网络以自旋构型样本为输入, 并正确标注样本所属的相, 见图 3.4(a). 标签通常编码成采用独热编码的二进制位串. 对 Ising 模型而言, 有序相 ($T < T_c$) 中抽取的全部样本标记为 1, 无序相 ($T > T_c$) 中的全部样本标记为 0.⁵ 为确保神经网络输出可用于预测二元标签, 输出层由两个节点组

⁵当然, 反过来把有序相标为 0、无序相标为 1 也同样可行.




图 3.4: 对不同线性晶格尺寸 L ($N = L^2$) 的 Ising 模型, 使用神经网络进行监督相分类 (更多细节见文献 [123]) . (a) 对 Ising 模型构型样本应用 (卷积) 神经网络. (b) 蓝、红曲线分别给出输出层两个节点的平均激活值. 两曲线交点标出预测临界温度; 它与橙色竖线表示的 Onsager 解 [式 3.5] 符合良好. 改编自文献 [123].

成, 并对其中所有节点的激活值 $\mathbf{x}_j$ 应用式 2.37 介绍的 softmax 激活函数. 这样可保证输出层编码的是类别上的有效概率分布. 预测标签通常取概率最大的节点所对应的标签. 训练时通常采用二元交叉熵 (见式 2.2); 对固定输入 $\mathbf{x}$, 它为

$$\mathcal{L} = - \sum_j p_j(\mathbf{x}) \log(\text{NN}(\mathbf{x})_j). \quad (3.12)$$

这里, $\text{NN}(\mathbf{x})$ 表示以 $\mathbf{x}$ 为输入、最后一层含 softmax 激活函数的神经网络输出. 求和遍历所有输出节点, 即所有不同类别. $p_j(\mathbf{x})$ 是独热编码给出的输入 $\mathbf{x}$ 的真实标签. 例如, 若有两个类别且某输入的真实标签为 0, 则 $p_0(\mathbf{x}) = 1$ 、 $p_1(\mathbf{x}) = 0$, 因而 $\sum_j p_j(\mathbf{x}) = 1$. 在式 3.12 中, 它与 $\text{NN}(\mathbf{x})_j$ 比较; 后者是第 j 个输出节点的激活值, 对应输入 $\mathbf{x}$ 属于类别 j 的预测概率.

在这个例子中, 训练集由远高于和远低于 T_c 的宽温度范围内带标签的自旋构型样本组成, 测试集则覆盖整个温度范围. 在训练集上训练神经网络 (见节 2.4.4) 后, 再在测试集上评估. 特别地, 对输出层两个节点在测试集上的激活值取平均; 它们分别编码输入样本属于相 0 或相 1 的概率. 值得注意的是, 图 3.4(b) 表明, 两条激活曲线恰在 T_c 处相交, 因此可以提取正确的临界温度. 类似地, 该方法也能正确识别 Ising 规范理论中的交叉温度 [123]. 神经网络对未见输入数据的泛化能力还可这样利用: 在方格晶格铁磁 Ising 模型构型上训练的网络, 同样能指出三角晶格等不同晶格几何下 Ising 模型的临界温度 [123]. 注意, 三角晶格上的铁磁 Ising 模型是受挫系统 (frustrated system) 的典型例子.

3.4 利用神经网络进行无监督相分类

在节 3.3 中, 我们说明了神经网络可以完成监督相分类. 由于其监督性质, 这种方法需要部分了解系统相图. 如果已知两个相邻相深处样本的标签, 就可以通过“插值”确定临界温度. 理想情况下, 为发现新的物质相, 相分类算法不应依赖关于各相的这类先验知识, 也就是说, 它在此意义上应当是无监督的. 聚类虽属无监督方法, 但其能力可能有限. 下面讨论三种使用神经网络进行无监督相分类的方法.




图 3.5: (a) 自编码器结构中自然瓶颈（此处为两个神经元）的示意图. (b) 对为重构二维 Ising 模型自旋构型而训练的自编码器，分析其瓶颈神经元. Ising 构型的潜在表示在直方图中聚成两个相. (c) 异常检测 (anomaly detection) 方案利用仅在一个相上训练的自编码器之重构损失恢复相图（左下角蓝框）. 分图 (b) 取自文献 [115]，分图 (c) 取自文献 [126].

3.4.1 利用自编码器学习

一种自然的神经网络无监督方法，是分析潜空间 (latent space) 中由自编码器给出的数据表示. 正如节 2.4.5 简要说明的，自编码器是中央带瓶颈、并以在输出端重构输入为训练目标的神经网络. 典型结构见图 3.5. 由于存在瓶颈，流经网络的信息必须在瓶颈处压缩，随后再解压以恢复输入. 压缩可能丢失一些信息,⁶ 但瓶颈中保留的信息理想地应包含重构输入所需的一切. 因此，瓶颈形成潜空间，包含输入数据的压缩表示. 这与前文讨论的降维方案类似（见节 3.2），后者保留对重构最重要的特征. 因而，可以像分析节 3.2.1 中 PCA 所得低维表示那样分析输入数据的潜在表示.⁷

把自编码器用于重构二维 Ising 模型的 Monte Carlo 样本 [115]. 由于没有提供任何标签，这显然是一种无监督相分类方案. 待最小化的损失函数是输入与输出自旋构型之间的重构误差，例如均方误差. 考察训练后自编码器中自旋构型的潜在表示如何随温度变化 [见图 3.5(b)]，可以立即观察到潜在参数发生聚类；这些簇对应 Ising 模型的两个相.⁸ 红点对应高温顺磁相，黄点对应低温铁磁相. 注意图 3.5(b) 直方图边缘的两个大黄

⁶一般而言，神经网络或许能把更多维度压缩进单个神经元. 然而在实践中，神经网络倾向于学习光滑函数，这会抑制此种行为.

⁷量子版本的自编码器也正在开发，并已用于相分类 [124] 以及 Hilbert 空间子空间的聚类 [125]. 更多细节见 paragraph 8.2.7.

⁸须注意，潜空间中的数据依系统所含各相聚类，并不是自编码器的一般性质. 当输入数据在瓶颈中引

色柱. 它们源于基态简并: 所有自旋要么都向上, 要么都向下.

分析输入数据的自编码器潜在表示, 并非用自编码器进行无监督相分类的唯一途径. 文献 [126] 提出了另一种成功而稳健的异常检测方案.⁹ 基本思路如下. 设想训练一个自编码器重构来自某一个相的状态, 再用它重构相图其余部分的状态. 由于训练数据只限于一个相, 这一任务很困难, 自编码器在其他相中必然产生重构误差. 此外, 与“训练”相相似的相应会有较小误差, 而包含外观很不相同状态的相应会有较大误差. 最后, 过渡区域中的量子态通常很有辨识度, 与相图其余部分最为不同. 因而, 仅在一个相上训练的自编码器, 其跨相图重构误差预期会随系统中的相及相边界而变化. 该方案可以完全无监督地发现相. 文献 [126] 用这种异常检测方案恢复了整数精确填充下一维扩展 Bose-Hubbard 模型的完整相图, 结果见图 3.5(c). 有趣的是, 他们还在相图中发现了一个具有意外性质的相分离区域 (phase-separated region),¹⁰ 这可能是机器学习引导的相分类中最早的完全无监督发现之一.

3.4.2 混淆学习

混淆学习 (learning by confusion) [128] 是另一种基于神经网络的无监督方法. 首先用不同标签把温度范围分成两个区域. 根据这些标签, 按照节 3.3 所述在整个温度范围上进行监督学习, 并记录模型最终的总体分类准确率. 这一准确率对应两个区域边界处的临界温度猜测. 对温度范围的多种二分方式, 即多种临界温度猜测, 系统重复上述过程. 最后, 画出分类准确率随猜测临界温度的变化. 算法 4 概括了这一过程. 注意, 每种划分都要训练一个独立的神经网络.¹¹ 对 Ising 模型应用该算法的结果见图 3.6. 分类准确率呈 W 形. 温度范围两端的高准确率, 是因为此时几乎所有样本都被赋予同一标签. 在所有样本都取同一标签的极端情况下, 分类准确率可以轻易达到 1, 因为神经网络只需学会无论输入为何都输出同一标签. 然而, 中间峰并非平凡结果, 它对应方法所预测的临界温度, 并与 Onsager 解符合良好. 中间峰可解释如下: 假设数据在温度范围的某种特定二分方式下能够自然分成两个不同群体, 则所选二分越接近数据内在的“正确”二分, 算法的分类准确率就越高.

起彼此有别的激活时才会发生聚类, 而这种情形往往对应不同的相.

⁹基于自编码器的异常检测方案也已成功用于量子动力学问题 [127].

¹⁰该相分离区域位于超固相与超流相之间, 详见文献 [126].

¹¹对每种二分选择重新训练模型, 可能在提高方法分辨率时带来很高的计算成本. 混淆学习方案的一项扩展使用两个神经网络 [129], 尝试以引导方式逐个选择二分点, 从而规避这一问题.




图 3.6: 对 Ising 模型应用混淆学习方案的结果. 数据由 100 个自旋构型 (线性晶格尺寸 $L = 30$) 组成, 它们通过 Monte Carlo 方法, 在从 $T_1 = 1$ 到 $T_{20} = 3.5$ 的等距温度点上采样. 数据集被等分为训练集和测试集 (使每个采样温度处有 50 个自旋构型). 蓝色曲线给出多种二分选择下测试集的分类准确率. 它具有典型的 W 形, 中间峰位于 $T \approx 2.3$, 与 Onsager 解符合良好. 据文献 [2, Notebook A3] 重现.

算法 4 混淆学习

输入: (自旋构型) 样本数据集 $\mathcal{D}_0 = \{\mathbf{x}\}$, 临界温度猜测 $\mathcal{T} = \{T_1, \dots, T_{\max}\}$

for $T_c^* \in \mathcal{T}$ **do**

 把数据集 $\mathcal{D}_0$ 分成 $T \leq T_c^*$ 与 $T > T_c^*$ 两个区域

 把 $T \leq T_c^*$ 区域中所有样本的标签 $\mathbf{y}$ 设为 0, 把 $T > T_c^*$ 区域中的设为 1

 把所得数据集分成训练集和测试集

 在训练集上进行监督学习, 即训练神经网络以最小化式 3.12 中的损失

 在测试集上评估分类准确率

end for

画出准确率随 T_c^* 的变化, $\forall T_c^* \in \mathcal{T}$ (见图 3.6) $\triangleright$ 准确率达到峰值处的临界温度 T_c^* 是相变位置的最佳猜测

以上讨论假定所考察参数范围内恰有两个不同相. 此时准确率理想地呈典型 W 形, 见图 3.6. 若存在多个相, 这一典型形状会发生改变. 信号形状, 特别是所得峰的数量, 可以用来识别数据中不同相的数目 [128, 130, 131].

3.4.3 基于预测的方法

混淆学习方案很难高效推广到可能含有多个不同相的高维参数空间.¹² 此外, 混淆学习方案难以正确识别 Ising 规范理论中的交叉 [121]. 所谓基于预测的方法 (prediction-based method) [132, 121, 122] 可以绕过这些限制, 其工作方式如下.

训练神经网络, 使其为每个构型样本预测调控参数 (tuning parameter), 此处即温度. 某个构型样本生成时的调控参数值, 在实验和模拟中都容易获得. 如果系统不发生

¹²文献 [129] 提出了一种把该方案推广到含两个不同相的二维参数空间的方法.




图 3.7: (a,b) 系统不发生任何相变时, 基于预测的方法之输出示意图. (c,d) 对 Ising 模型应用该方法的结果. 数据由 100 个自旋构型 (线性晶格尺寸 $L = 30$) 组成, 它们通过 Monte Carlo 方法, 在从 $T_1 = 1$ 到 $T_{20} = 3.5$ 的等距温度点上采样. 数据集被等分为训练集和测试集 (使每个采样温度处有 50 个自旋构型). (c) 测试数据的平均预测温度随真实温度的变化. (d) 平均预测温度对真实温度的导数; 它在 Ising 模型的临界温度处达到峰值. 分图 (b)、(c) 据文献 [2, Notebook A3] 重现.

任何相变, 预测调控参数与真实调控参数呈线性关系, 如图 3.7(a) 所示. 因而预测调控参数对真实调控参数的导数为常数, 见图 3.7(b). 对发生相变的系统, 情形则不同. 此时调控参数无法完全准确地预测, 导致预测值与真实值之间呈非线性关系. 图 3.7(c) 以 Ising 模型说明了这一点. 相应导数并非常数, 而在临界调控参数处变化率最大, 见图 3.7(c)、(d). 换言之, 神经网络预测最敏感的参数值标定了相变位置.

再详细说明这一点: 调控参数在相变附近仅有微小变化, 但当它越过临界值时, 系统状态及相应序参量会剧烈改变. 因此, 神经网络最善于区分来自两个不同相的样本, 却难以区分同一相内的样本. 也就是说, 当调控参数扫过临界值时, 其预测变化最大. 图 3.7(c) 表明, 预测在各相深处开始饱和, 而在转变点附近随调控参数变化最强.

到目前为止, 我们看到, 基于神经网络的相分类方法能够定位二维 Ising 模型的相变. 这些方法迄今还成功揭示了多种物理系统中的许多其他相变.¹³ 这凸显了这些方法具有普适性, 并以系统无关 (system-agnostic) 的方式构建. 或许存在磁化强度等多种物理可观测量可用于识别给定相变, 但寻找这些量通常很困难, 需要深入理解所研究的物理系统. 值得注意的是, 这里展示的神经网络方法无需关于底层物理的先验知识, 便能自动对不同物质相进行分类. 也有不依赖机器学习的类似系统无关工具, 例如热相变

¹³还有许多其他用于探测相变和物质相分类的机器学习方法 [133, 134, 135, 136, 137, 138, 122]. 例如, 文献 [135] 在一个相内训练机器学习模型拟合其性质, 并向参数空间其他区域外推, 由此推断相变. 该模型基于采用核的 Gaussian 过程. 我们将在章 4 详细讨论包括 Gaussian 过程在内的核方法.

的比热，或量子相变的保真度易感率 (fidelity susceptibility) [139].¹⁴ 然而，这些工具对特定系统仍可能失效，而且计算成本可能很高，或在实验中难以测量。例如，比热无法定位 Ising 规范理论中的交叉温度。对保真度易感率，需要研究重叠 $\langle \Psi_0(p) | \Psi_0(p + \epsilon) \rangle$ 的变化，其中 $|\Psi_0(p)\rangle$ 是 Hamiltonian $H(p)$ 的基态， p 为调控参数， ϵ 为无穷小扰动。由于通常无法获得完整波函数，保真度易感率往往仍难以计算。上述神经网络方法构成了另一类工具。原则上，它们可以把不同调控参数值下系统状态的多种性质作为输入，从而根据实验可及的测量数据识别相变 [140, 141, 106]。

尽管目前讨论的相分类方法能够定位相变，我们尚未了解系统所经历相变的具体类型。关键问题是，能否从神经网络中提取与底层相分类任务有关的物理见解。特别是，能否从这类网络中提取新的序参量；这是可解释机器学习应用于相分类问题时的终极目标。

3.5 机器学习模型的可解释性

如前几节所见，神经网络是从物理数据中识别物质相的强大工具。现在设想把这些方法用于一个新的物理系统，而其物质相和相应序参量尚不为人知。自然会出现以下问题：我们能相信神经网络的预测吗？特别地，如何知道模型在参数空间中正确定位了相变？再者，假设这些方法已把数据正确分入不同物质相，我们如何获得相关问题的物理见解？例如，能否分析训练后的神经网络，以确定系统经历了何种相变？甚至能否从中提取新的序参量？使用机器学习模型，特别是深度学习模型时，这些问题并不容易回答。机器学习的可靠性 (reliability) 与可解释性 (interpretability) 研究正在应对这些挑战。¹⁵

可靠性关乎是否信任机器学习模型的预测。例如，当我们能够获得模型预测的不确定性时，对模型的信任就会增强。可解释性关乎理解机器学习模型学到了什么，以及它如何作出预测。因而，这两个概念紧密交织。

在利用机器学习走向科学发现的道路上，这两个概念都格外重要。如果我们无法理解神经网络面对问题时学到了什么，我们对这个问题的理解就仍然有限！¹⁶

前文已经提到，深度学习模型先验地通常既不可靠，也不可解释。因此，它们很大程度上只是黑箱模型，为我们提供合适的预测，例如据此定位底层输入数据中的相变。原因有几个：首先，其学习动力学大多不透明，也没有得到充分理解。¹⁷ 其次，直接分析训练后的神经网络很困难，下一小节将对此说明。特别地，神经网络的“推理”未必基于人类作决定时所依据的同一组观察。应对这些挑战对所有机器学习应用都很重要，而对医疗诊断、保险或招聘决策等应用尤其关键。

¹⁴量子相变 (quantum phase transition) [98] 是指调控参数临界值 p_c 处基态性质出现非解析行为，其中系统 Hamiltonian 为 $H(p)$ 。它源于依赖调控参数的 Hamiltonian 中各项之间的竞争。

¹⁵物理学界和计算机科学界都尚未就这些术语的正式定义达成共识 [142]。为绕开这一问题，这里给出对其含义的直观理解。

¹⁶可以设想一个不可解释的黑箱神经网络，训练后仍能为问题提供见解，例如文献 [143]。然而，模型仍须可靠，我们才能相信新见解；而且我们还需要事先对问题有深入认识。

¹⁷在节 8.1 中，我们将说明如何用统计物理工具回答其中一些问题。

3.5.1 解释模型参数的困难

面对可能含有数十亿个可训练参数的深度神经网络，人类很难辨明神经网络内部究竟在做什么。神经网络可能确实计算了某个简单且具有物理意义的函数，例如序参量，并以此作出预测。但要判断是否如此并不容易，因为计算和相关信息分散在许多层中，而每层又含有大量神经元。不过，如果神经网络足够小，直接考察其可训练参数或许能够解释模型。考虑没有任何非线性激活函数的单层神经网络这一极限情形。它对应节 2.4.1 所述的简单线性回归模型：

$$\hat{y} = \mathbf{w}\mathbf{x} + b. \quad (3.13)$$

其中， $\mathbf{w}$ 是权重向量， b 是偏置向量。显然，这种线性模型允许直接依据权重加以解释：某一权重（连接）的绝对值越大，相应的归一化特征对解决当前问题就越重要。相分类语境下解释权重的例子见文献 [144]。

然而，降低深度并丧失非线性，是以表达能力为代价的。为使这类模型达到较高准确率，通常需要对输入 $\mathbf{x}$ 作大量预处理，由预处理承担所需的非线性。此外，只有当某个特征已经以紧凑且具有物理意义的形式存在时，其重要性才更有意义。这在很大程度上把小型预测模型的适用范围限制于我们至少部分了解的问题。

获得有效参数数目较少的神经网络的一种方法是正则化，特别是在损失函数中加入 ℓ_1 正则项 $\ell_1 = \lambda \sum_i |w_i|$ ，其中 λ 参数化正则化强度，求和遍历神经网络中的全部可训练权重。该项迫使权重趋于零，也就是切断连接。理想情况下，这会得到更稀疏、因而有效规模更小且可以解释的神经网络。例如，文献 [145] 的作者从为预测行星和暗物质动力学而训练的图神经网络中，提取了力定律和暗物质分布的解析表达式。这是通过对相应稀疏网络作符号回归（symbolic regression）实现的。¹⁸ 正则化对解释式 3.13 这样的线性模型也很重要。学习问题通常没有唯一解；这意味着，即使数据和优化过程相同，权重仍可能变化，从而对神经网络的内部机制产生不同的“解释”。正则项有助于消除权重剩余的自由度，并实施 Occam 剃刀原则。

有一大类机器学习算法可直接依据模型参数解释，支持向量机就是如此，见节 2.4.3 和节 4.2.2。文献 [146] 首次提出用支持向量机解决相分类任务，随后又把它推广并用于高阶自旋系统 [147, 148]。如上所述，尽管这类算法可能不如神经网络强大，但其主要优势在于能够获得可解释的决策函数，并从中推断序参量。¹⁹

3.5.2 通过瓶颈实现可解释性

正如上一小节所述，可解释性是小模型的内在特征。幸运的是，还有不局限于简单小模型的可解释性方法。对大型架构，可以识别信息流中的瓶颈并把注意力集中于此。神经网络中的瓶颈，就是神经元数少于前后两层的一层。节 3.4.1 和图 3.5(a) 已经给出

¹⁸图神经网络与卷积神经网络相似之处在于，输入的空间位置对输入含义至关重要。在卷积神经网络中，邻居由输入数据网格中的位置决定；在图神经网络中，则可通过图节点间的自定义连接更广泛地定义邻居。神经网络层可以作用于每个节点，也可以通过节点间的消息传递起作用。

¹⁹决策函数确定给定样本 $\mathbf{x}$ 到超平面的距离。




图 3.8: 分析为重构二维 Ising 模型自旋构型而训练的自动编码器之瓶颈神经元. (a) 潜在空间参数对磁化强度的依赖关系. 红色 (黄色) 对应来自低温 (高温) 区域的样本. (b) 在固定温度下取平均的磁化强度绝对值、潜在参数经重缩放后的绝对值, 以及重构损失. 改编自文献 [115].

具有自然瓶颈的神经网络例子, 即自动编码器. 其瓶颈迫使神经网络提炼输入中的相关信息, 使其能够通过这一狭窄通道. 于是, 神经网络完成降维, 并找出合适的低维特征表示. 整个神经网络架构可以很大, 含有许多可训练参数, 但瓶颈本身可能只有少数几个参数. 由于神经网络预测所需的全部相关信息最终都必须流经瓶颈, 我们可以只分析瓶颈中的少量可训练参数, 而不是整个神经网络.

特别地, 可以对这些瓶颈神经元的输出作回归, 提取输入特征与瓶颈神经元激活值之间的映射. 几乎每个神经网络都有一个自然瓶颈, 即输出神经元. 然而, 如果不施加其他瓶颈, 要对它作回归并不容易, 因为必须考虑可能迅速增多的全部输入特征. 除输出神经元外, 其他类型的瓶颈也会自然出现在神经网络架构中, 例如自动编码器 (见节 2.4.5) [115, 149] 和卷积神经网络 (见 paragraph 2.4.4) [150]. 我们也可有意在架构中引入瓶颈, 以得到更可解释的机器学习模型. 例如, 这一思路催生了 Siamese 神经网络 [151]. 下面更详细地考察这些方法, 看看能用它们从物理系统中提取什么信息.

正如节 2.4.5 和节 3.4.1 所述, 自动编码器是中央带有瓶颈、以在输出端重构输入为训练目标的神经网络. 节 3.4.1 和图 3.5(b) 已经表明, 可以在潜在表示中得到与输入数据所含各相对应的聚类, 从而实现无监督相分类. 此外, 瓶颈理想地应包含重构所需的全部相关信息, 因此还能提取更多信息, 解释自动编码器保留了输入数据的何种性质. 特别地, 如果像图 3.8(a) 那样, 画出潜在参数随相应二维 Ising 自旋构型磁化强度的变化, 就会看到线性依赖. 这表明自动编码器学到的压缩表示与磁化强度有关. 更确切地说, 在磁化强度接近 -1 时, 其行为偏离严格的线性关系. 然而, 由于潜在参数与磁化强度之间的映射是双射, 仍可以断言自动编码器学到了与磁化强度有关的性质. 例如, 即使潜在参数作为磁化强度的函数按 sigmoid 函数变化, 这一断言依旧成立.

Iten 等人 [149] 的工作是分析自动编码器潜空间的另一个例子. 他们使用了一种带有问题神经元 (question neuron) 的特殊自动编码器架构, 即在瓶颈之后额外连接到第




图 3.9: (a) 解释网络；每一步训练都系统缩小感受野. 定位网络由一个或多个连续卷积层组成，平均层把卷积后的特征压缩为单个数. (b) Siamese 神经网络（Siamese neural network）示意图；两个子网络完全相同，并共享同一组可调参数. 输入是一对数据点，所得标签为“相同”或“不同”. 分图 (a) 改编自文献 [150].

一解码层的神经元. 问题神经元的输入由用户提供，可视为向网络提供数据的另一途径. 作者表明，可以这样训练特殊自动编码器：用户通过问题神经元提问，答案则编码在潜空间中.

由此可见，由于潜空间维数较低，自动编码器在一定程度上具有内在可解释性. 然而，分析潜空间不会直接提示序参量或重要特征；只能把它同我们怀疑重要的量或特征作比较. 若希望以更自动化的方式探测序参量，可以转向一类非常特殊的卷积神经网络.

前文已经提到，卷积神经网络的架构中存在自然瓶颈. 这些瓶颈就是滤波器或核，即网络用来“扫描”数据的结构. 其尺寸可视为感受野（receptive field）大小，它说明网络一次能够分析多少个相邻特征，例如像素. 当然，如果多个卷积层带有多个不同尺寸的核，并与池化层交织，其分析仍很困难. 但若考虑一个简单卷积神经网络，它只有一个或少数几个连续卷积层，各层核尺寸固定，且架构末端只有一个平均层，这种回归就变得可行.²⁰ Wetzel 等人（2017）[150] 提出了这一架构，称为解释网络（Interpretation Net）或关联探测神经网络（Correlation-Probing neural network），见图 3.9(a). 这种架构允许用核提取的特征对输出神经元作回归，最终得到卷积神经网络决策函数的解析表

²⁰它仍非平凡过程，需要仔细地把权重重置零、使用 Fourier 级数及其他技巧. 感兴趣的读者可参见文献 [150].




图 3.10: 关联器卷积神经网络 (Correlator convolutional neural network) 具有可通过正则化启用或停用的可学习滤波器. 输入先同学得滤波器作卷积, 产生一组卷积图; 随后可以从中递归构造高阶局域关联的信息. 取自文献 [152].

达式. 若把它用于相分类问题, 这种决策函数就可能揭示序参量. 然而, 决策函数以及卷积神经网络可能发现的序参量, 似乎依赖于核尺寸的选择. 那么, 核尺寸和决策函数应如何选择? Occam 剃刀原则告诉我们, 应关注最简单的决策函数, 也就是只考虑少量输入特征; 关键是, 这也使符号回归任务更容易.

因此, 解释网络的思想是系统缩小核尺寸 (从而降低符号回归任务的输入维数), 逐步切断连接, 直到卷积神经网络性能显著下降. 这种下降对应卷积神经网络对探测和区分不同相至关重要的关联变得“盲目”.

设想从尺寸等于整幅输入图像大小的核开始, 例如 28×28 . 用这种核训练解释网络并发现结果良好. 随后把感受野缩小到例如 20×20 , 重新训练并观察性能. 重复缩小核尺寸和重新训练, 直至卷积神经网络性能显著下降. 一旦卷积神经网络看不到系统中对相分类至关重要的关联, 例如次近邻关联, 就会出现这种下降. 最后, 可以用仍保持良好性能的最小核尺寸, 对卷积神经网络的输出神经元作回归. 由此恢复的决策函数理想地与底层序参量有关. 采用这种方法, 解释网络能够成功区分二维 Ising 模型²¹或 $SU(2)$ 晶格规范理论的物质相, 并提取相应决策函数. 我们强调, 学得决策函数可能强烈依赖网络架构、训练过程以及可用数据的选择. 因此, 不同网络可能探测不同序参量; 例如在 Ising 模型中, 它们可能探测每个格点的期望能量、磁化强度或二者经缩放后的组合.

Miles 等人 (2021) [152] 设计图 3.10 所示关联器卷积神经网络时采用了相关方法. 该网络在最初几层中探测单体、二体和高阶关联, 从而自动完成特征工程; 后续各层用于检查哪些关联对分类最重要. 网络同样通过调整神经网络能够学到什么, 而对某些特征变得盲目. 与前一种方法不同, 作者通过正则化惩罚某些滤波器的学习. 增大正则化

²¹有趣的是, 在原论文中, 对 Ising 模型而言带来较好卷积神经网络性能的量, 是每个格点的期望能量 $(-J/N) \sum_{\langle i,j \rangle} \sigma_i \sigma_j$; 它仍可由 2×1 核探测, 而磁化强度 $(1/N) \sum_i \sigma_i$ 则仍可由 1×1 核探测.

强度，就能根据特征对预测准确率的重要性依次停用它们，从而得到与底层物理相对应的重要关联层级。

关联器卷积神经网络被用于探测两个理论量子模型之间起区分作用的关键多体关联器；这两个模型是近似描述掺杂 Fermi–Hubbard 模型的候选理论 [152]。它由此解释了另一项工作 [143] 的结果：该工作训练卷积神经网络区分依据两种候选理论数值生成的量子系统快照，再用训练后的网络测试实验快照，判断两种理论量子模型中哪一种能更好描述这些快照。这是使用神经网络作出科学发现的最早实例之一。

还可以考虑带有人为瓶颈、并允许通过符号回归解释的更复杂架构。一个有趣的例子是 Siamese 神经网络 [151]，有时也称孪生神经网络，见图 3.9(b)。它同时接收两个输入数据点，由参数和架构均相同的两个孪生子网络组成。两个输出神经元形成两个瓶颈，再作为第三个子网络的输入；第三个子网络负责连接并比较这两个孪生输出。网络的任务是判断两个输入数据点是否相似。²² 这意味着 Siamese 神经网络无须先验固定类别数目，并且每类只需较少训练数据，就能完成多类别分类。此外，通过分析瓶颈，可以提取神经网络在问题中学到了什么。

这类网络为以无监督方式发现相变提供了强大工具，见文献 [154, 155]。用 Siamese 神经网络学习相变与使用卷积神经网络非常相似。但由于其无监督性质，不能提供物质相标签。因而，标签初始化方式是：从相图同一点采样的数据对取“相同”标签，来自相图不同点的数据对取“不同”标签。训练后，可以从相图相邻点抽取样本对，并预测它们“相似”还是“不同”，从而用 Siamese 神经网络探测相边界。不相似度的尖峰便标志着相变。

结束本节前，再考察几个相分类以外的应用，其中通过瓶颈解释神经网络同样有用。文献 [151] 的作者把 Siamese 神经网络用于中心势中粒子的运动。任务是学习粒子的两次观测是否对应同一条粒子轨迹，还是两条不同轨迹。成功训练后，可以用输入数据特征对瓶颈作多项式回归。此处特征由粒子在二维空间中的位置及其二维速度向量组成。通过分析占主导地位的回归项，他们观察到回归结果正比于粒子的角动量。对成功训练的 Siamese 神经网络作这种瓶颈分析，表明网络学到了守恒量和不变量。²³ 特殊相对论和电磁学问题也能得到类似结果 [151]。²⁴

至此，我们学会了通过分析架构中的瓶颈来解释机器学习模型。这些瓶颈既可自然出现，例如自动编码器中的瓶颈；也可显式施加，例如系统缩小卷积神经网络的核尺寸，或在 Siamese 神经网络中设置瓶颈。另一种实现可解释性的方法，是分析模型优化期间到达的训练损失函数极小值。由于这种分析以极小值为基础，因此它具有普适性，不依赖机器学习模型架构或学习过程的具体选择。

²² 文献 [153] 开发了 Siamese 神经网络的量子版本；有趣的是，它超越了基于距离的相似性概念。

²³ 由输入特征的多项式函数表示的不变量更容易探测。

²⁴ 利用机器学习寻找对称不变量和守恒量已经形成独立子领域，并出现了许多改进的探测方法 [156, 157, 158]。




图 3.11: (a) 在 CIFAR-10 上训练的深度学习 VGG-56 之非凸损失景观的低维可视化, 取自文献 [44]. (b) 用于提高训练后机器学习模型可解释性和可靠性的 Hessian 工具箱. 它以训练损失在极小值处的 Hessian (或其近似) 为基础. 改编自文献 [164].

3.5.3 基于 Hessian 的可解释性

如节 2.1 所述, 机器学习模型通过改变参数 θ , 最小化描述问题的训练损失函数 $\mathcal{L}$ 来学习. 然而, 深度神经网络的训练损失景观 (training loss landscape) 高度非凸; 例如, 其中存在许多局域极小值, 这会使优化问题变得困难 [见图 3.11(a)]. 此外, 这些极小值的泛化能力未必相同, 而这种能力似乎与极小值附近的曲率有关.²⁵ 这种联系说明, 到达的极小值之形状可以告诉我们关于训练后机器学习模型的有用信息. 极小值 $\theta = \theta^*$ 附近的形状或曲率, 由在该极小值处计算的 Hessian 矩阵描述:

$$H_{\theta^*, ij} = \frac{\partial^2}{\partial \theta_i \partial \theta_j} \mathcal{L}_{\text{train}} \Big|_{\theta=\theta^*}. \quad (3.14)$$

了解极小值附近的曲率, 还能近似判断采取某种操作后机器学习模型以及相应预测会如何变化. 可能的操作包括删除单个训练点, 或者把模型参数从 θ^* 略微改为 $\tilde{\theta}$, 移向训练误差相同的相邻极小值. 研究模型如何响应这类操作, 是图 3.11(b) 所概括的 Hessian 工具箱之核心. 该工具箱包含影响函数 (influence function) [165]、重采样不确定性估计 (resampling uncertainty estimation, RUE) [166] 和局部集成 (local ensemble, LE) [167]; 下面介绍它们的概念性思路.

影响函数近似一种称为留一训练 (leave-one-out training) 的过程,²⁶ 并估计: 从训练集中删除某个训练点 $\mathbf{x}_R$ 后, 模型对测试点 $\mathbf{x}_{\text{test}}$ 的预测如何变化. 这种删除可能产生三种结果:

1. 预测保持不变, 因为被删训练点不影响模型预测;
2. 预测改善, 即 $\mathbf{x}_{\text{test}}$ 上的测试损失降低, 因此对 $\mathbf{z}_{\text{test}}$ 作预测时, $\mathbf{x}_R$ 是“有害”训练点;

²⁵人们普遍认为, 宽而平坦的极小值比尖锐极小值具有更好的泛化能力 [159, 160, 161, 162]. 但应注意, 平坦性在深度模型的非凸景观中尚不是一个发展完善的概念 [163].

²⁶对具有非凸损失景观的深度学习模型进行留一训练很棘手, 因为若落入另一个局域极小值, 就无法断言删除单个训练点所造成的扰动. 因此, 重新训练时通常须谨慎地从原模型到达的极小值出发.

3. 预测变差, 即 $\mathbf{x}_{\text{test}}$ 上的测试损失增大, 因此对 z_{test} 作预测时, $\mathbf{x}_R$ 是“有益”训练点; 删除它使构造准确模型更加困难.

通过这种分析, 可以确定训练数据点对测试点预测的影响程度, 从而得到模型如何推理的线索. 甚至还可以进一步说, 如果两个数据点彼此影响很强, 那么从模型视角看, 它们就很相似.²⁷ 机器学习模型学得的这种相似性, 可以理解为模型内部表示中数据点之间的距离; 它是探测错误标注数据中的额外物质相 [168, 106]、探测有影响力的特征 [106] 以及探测异常 [164] 的强大工具.²⁸

Hessian 工具箱的另一种工具是重采样不确定性估计 [166], 其目标是估计模型预测的不确定性 (uncertainty). 它是经典自助法 (bootstrapping) 的近似. 从原始训练集开始, 其中每个训练数据点各出现一次. 设想从原数据集中进行均匀有放回抽样, 构造 b 个新训练集. 由于采用放回抽样, 新集合中有些训练点出现不止一次, 另一些则被遗漏. 随后, 可以在这 b 个训练集上训练 b 个模型, 并对同一测试点 z_{test} 作出 b 次预测. 由于训练集彼此不同, 这些预测一般会发生变化. 计算它们在 z_{test} 上的方差, 就得到原模型预测不确定性的估计. 方差较小表示原模型的预测可信, 因为对训练集作微小随机改动不会使预测发生太大变化. 方差较大则表明预测只基于少量训练点, 因而不可靠. 文献 [164] 展示了这类误差棒如何表征量子相变的尖锐程度.

最后, 局部集成 [167] 可以探测给定模型在测试点处的欠规范性 (underspecification). 如果某个测试输入处有许多不同预测都同训练数据和学习问题规范 (即模型架构与损失函数) 施加的约束同等相容, 那么训练后的模型在该输入处就是欠规范的. 如节 2.1 所述, 优化到达的极小值通常被大体平坦的景观包围. 这意味着, 即使模型最终落在某个平坦的相邻点, 训练误差也会完全相同. 因而, 这种变化不应影响预测, 除非预测是未充分确定的 (underdetermined), 即不稳定且无法由训练数据良好解释. 所以, 可以再次对原模型参数作微小移动, 构造多个模型; 这些新模型探索原极小值附近的平坦景观, 随后用它们作出预测. 如果测试点 z_{test} 上的预测因这类改动而改变, 该点就可能是分布外点 (out-of-distribution point), 即来自一个与训练数据底层分布显著不同的分布. 局部集成可以探测这类分布外测试点, 从而提高机器学习模型的可靠性. 此外, 文献 [167] 的作者成功把局部集成用于主动学习: 反复加入局部集成探测到的欠规范性分数最高的测试点, 从而构造出小得多但信息量相近的训练数据集.

因此, 我们回答了最初关于可解释性的问题: 确实可以查看机器学习模型的黑箱内部. 如果把注意力集中于神经网络架构中的瓶颈, 就能用回归方法判断哪些量在神经网络预测中占主导地位. 此外, 也可以解释神经网络早期层中的滤波器. 如果这些量具有物理意义, 就可以论证神经网络确实依据物理上相关的量作出预测. 还可以把注意力转向训练损失极小值附近的曲率; 它包含模型学得的相似性信息, 并允许估计不确定性.

²⁷这一论点有影响函数几何解释的充分支持, 详见文献 [164] 第 2.3.3 节.

²⁸需要强调, 相似性大概是分类任务背后的核心概念, 但在 Siamese 神经网络、影响函数和核方法 (下一章介绍) 中具有不同含义.

3.5.4 相分类的概率视角

在节 2.3 中，我们介绍了机器学习的概率视角。把机器学习用于物质相分类任务时，这一视角尤其有用。下面聚焦于监督学习这一简单情形（节 3.3）。不过，该思路也可推广到其他基于神经网络的相分类方法，例如混淆学习（节 3.4.2）或基于预测的方法（节 3.4.3），见文献 [169, 170]。首先考虑在监督设定下区分猫和狗图像的情形。由节 2.3 可知，Bayes 分类器输出

$$y_{\text{Bayes}}(\mathbf{x}) = \arg \max \{p(\text{cat} | \mathbf{x}), p(\text{dog} | \mathbf{x})\}. \quad (3.15)$$

其中， $p(\text{cat} | \mathbf{x})$ 和 $p(\text{dog} | \mathbf{x})$ 分别是给定样本 $\mathbf{x}$ 为猫或狗的概率。Bayes 分类器是最优分类器，因为它在当前分类任务中优于任何其他分类器，也就是达到最低可能误分类概率。然而，对猫狗图像等大多数现实数据集，真实的类条件概率（class-conditional probability）是无法获取的抽象量，我们先验地不知道它们及其形式。因而，一种解决分类任务的方式，是用神经网络参数化这些条件概率，并训练网络以最小化误分类概率，即相应损失函数。由于神经网络是通用函数逼近器，随着网络表达能力增强、训练改善和数据集增大，其预测应当趋近 Bayes 分类器的预测。类似地，神经网络的误分类概率应从上方趋近 Bayes 误差。

如上所述，在现实情形中通常无法构造 Bayes 分类器。有趣的是，当进入物理学领域，特别是统计物理和量子物理领域时，情况可能发生变化；分类不同物质相这一任务的底层数据正来自这些领域。为说明这一点，考虑希望区分两个相（相 A 和相 B）的监督学习情形。Bayes 分类器的最优输出为

$$y_{\text{Bayes}}(\mathbf{x}) = \arg \max \{p(\text{phase A} | \mathbf{x}), p(\text{phase B} | \mathbf{x})\}. \quad (3.16)$$

利用式 2.19 中的 Bayes 规则，有

$$p(\text{phase A} | \mathbf{x}) = \frac{p(\mathbf{x} | \text{phase A}) p(\text{phase A})}{p(\mathbf{x})}, \quad (3.17)$$

相 B 的情形类似。假设数据集中两个相在标签方面具有相同代表性，则 $p(\text{phase A}) = p(\text{phase B}) = 1/2$ 。此外，

$$p(\mathbf{x}) = p(\text{phase A})p(\mathbf{x} | \text{phase A}) + p(\text{phase B})p(\mathbf{x} | \text{phase B}). \quad (3.18)$$

把它代入 Bayes 规则，得到

$$p(\text{phase A} | \mathbf{x}) = \frac{p(\mathbf{x} | \text{phase A})}{p(\mathbf{x} | \text{phase A}) + p(\mathbf{x} | \text{phase B})}. \quad (3.19)$$

因此，如果知道在两个相中抽到样本 $\mathbf{x}$ 的概率，即知道 $p(\mathbf{x} | \text{phase A})$ 和 $p(\mathbf{x} | \text{phase B})$ ，就能计算类条件概率，也就是 Bayes 分类器的最优预测。²⁹ 记从相 A 变化到相 B 时改变的物理参数为 γ ，并假设在不同点 $\{\gamma \in \text{phase A/B}\}$ 对相 A/B 采样。则

$$p(\mathbf{x} | \text{phase A}) = \frac{1}{|\{\gamma \in \text{phase A}\}|} \sum_{\gamma \in \text{phase A}} p_{\gamma}(\mathbf{x}), \quad (3.20)$$

²⁹同样可以把 Bayes 规则用于猫和点图像的分类任务。此时，为构造类条件概率，需要知道 $p(\mathbf{x} | \text{cat})$ 和 $p(\mathbf{x} | \text{dog})$ ；这些量抽象且无法获取，因此不适用这里的讨论。

其中, $|\{\gamma \in \text{phase A}\}|$ 是相 A 中不同采样点的数目, 相 B 类似. 这表明, 可以依据底层物理系统在调控参数 γ 的不同取值处采样所得的概率分布 $p_\gamma(\mathbf{x})$, 表示 $p(\mathbf{x} | \text{phase A/B})$, 进而表示类条件概率. 这些概率分布具有明确物理意义, 我们往往完全或至少部分了解它们.³⁰ 例如, 分析不同温度下处于热平衡的系统时, 如 Ising 模型 (节 3.1.1) 或 Ising 规范理论 (节 3.1.2), 我们知道底层分布是式 3.2 中的 Boltzmann 分布. 类似地, 研究量子相时, 或许可以获得支配测量统计的量子态波函数.

从这一视角看, (最优) 相分类任务归结为刻画当前物理系统的底层概率分布. 相变表现为这些概率分布的快速变化. 这为把数据分入不同物质相提供了另一条途径, 即先估计 $p_\gamma(\mathbf{x})$, 而不是直接尝试估计 $p(\mathbf{x} | \text{phase A})$ 和 $p(\mathbf{x} | \text{phase B})$; 它也从不同角度审视“传统”的神经网络相分类. 关于相分类概率视角的更完整综述, 见文献 [169, 170].

3.6 展望与开放问题

过去五年中, 已有许多工作把监督和无监督相分类算法应用于具有已知物质相的模型, 包括监督学习 (节 3.3)、混淆学习 (节 3.4.2) 和基于预测的方法 (节 3.4.3). 然而, 只有少数工作把无监督相分类方法用于实验数据. 此外, 使用无监督相分类方法发现新物质相仍有待实现. 这将是迈向科学发现自动化的重要一步.

近年来, 相分类方法的可解释性已经取得显著进展, 但我们对这些方法仍缺乏更深入的理解. 特别是, 仍然难以判断某种给定方法何时以及为何会失败或成功 [169]. 鉴于我们的目标是实现科学发现自动化, 并且相分类方法已经展现出处理范围广泛的物理系统的能力, 弥补这些认知缺口并开发相应的可解释性工具至关重要.

延伸阅读

- Carleo, G. *et al.* (2019). *Machine learning and the physical sciences*. Rev. Mod. Phys. 91, 045002. 该文第 4C 节概述了相分类领域的现状 [5].
- Neupert, T. *et al.* (2021). *Lecture notes: Introduction to machine learning for the sciences*. 面向科学工作者介绍机器学习基础和聚类算法 [94].
- Molnar, C. (2019). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. 一本关于可解释机器学习的入门书 [171].
- 关于相分类的 [Jupyter notebook](#) [2].

³⁰在实验情形中, 可能无法直接获得分布. 然而, 物理学家会尽最大努力分离并刻画其实验实现的经典统计系综或量子态.

高斯过程与其他核方法

本章讨论所谓的核方法，其中支持向量机和高斯过程是两个突出的例子。希望深入了解机器学习核方法基础的读者，可参阅示范性但远非详尽的文献汇编 [172, 173]；较高层次的综述见文献 [174]。

当标注数据数量有限时，这些方法尤其适用。这种情形通常出现在构建大型数据集需要耗费大量金钱、时间或人力等资源时。它们的第二项优势是，高斯过程的预测在构造上伴随不确定性，而其他方法并不直接提供这种信息。我们将在节 4.2 中看到，这一性质如何源于模型的设计选择。

不过，首先必须介绍本章所有方法都不可或缺的核 (kernel) 这一概念。引入核以后，我们能够处理的问题范围会显著扩大。在严格定义核的数学基础之前，先依据核技巧 (kernel trick) 及其含义，对实践中如何使用核给出直观说明。随后，我们说明如何通过核技巧扩展前述方法，并讨论如何根据数据训练其中每种方法。例如，事实表明可以从信息论视角研究高斯过程。此外，我们还会解释如何运用信息论概念指导数据采集，以及如何从多种可能模型中选择良好模型。本章最后将在节 4.5 中展示这些方法解决量子问题的能力。

4.1 核技巧

如节 2.4 所示，线性回归模型或线性支持向量机等简单方法，在数据性质方面受到严重限制。它们直接应用于原样输入数据，也就是说，受制于输入数据的给定表示。为避免后文混淆，我们把这种数据空间称为输入空间 (input space)。例如，在输入空间中，给定输入数据可能不是线性可分的。一种可能的补救办法是先把输入数据变换到另一个特征空间 (feature space)，从而增强模型的分类能力。与章 1 中的用法不同，以下内容明确区分输入空间与特征空间。¹ 理想情况下，与原始表示相比，数据在新表示中具有更便利的结构。例如，原先并非线性可分的数据，在新空间中可能线性可分。特别地，把数据变换到更高维特征空间通常很有用；数据此时嵌套在一个（理想地）具有有益附加结构的流形上。

人们或许会认为，这会使机器学习的代价极高；如果特征空间维数趋于无穷，甚至会使其不可行。然而，我们可以利用这样一个事实：所关注机器学习算法的预测，常常用输入空间中数据之间的距离表述。

核技巧正是在这里发挥作用：我们不显式地把数据变换到特征空间、再计算其中的距离，而是从另一端入手，用输入空间中的数据表示给出距离的闭式表达式。从数值角度看，这通常高效得多。

¹数据点的每个元素仍称为特征；不过，本章只关心寻找最便利的数据表示，因此把这种表示所在的空间称为特征空间。

如下文所示，总能为任何有效距离函数关联唯一的特征空间。因此，我们把关注点从寻找合适表示转移到选择合适的距离函数。这种技巧称为核技巧，是因为核就是同这类特征空间相关联的数学对象。所以，核技巧让我们能够以可控的计算代价，保留高维特征空间的全部优点。此外，下一节将会看到，核的数学基础为上述动机提供了严格的解析保证。

从实践角度看，表示定理尤其重要：到目前为止，我们希望寻找合适的变换，即寻找一个能够简化当前任务的函数。但如何优化函数而非参数并不明确。表示定理同时赋予我们这两方面的能力：实质上，它保证函数空间上的优化等价于优化某个闭式解的系数，进而让我们能够设计可行的数值优化程序。

下面先从一个直观例子入手，说明变换到特征空间为何以及如何带来益处。随后，我们严格介绍核的数学概念，由此获得理解表示定理所需的解析工具。

4.1.1 核技巧背后的直观认识

为建立直观认识，考虑图 4.1 所示带标签的二维数据集。在这个玩具例子中，黑线表示底层决策边界，即分开具有不同标签之输入数据的线。在更高维情形中，决策边界推广为超平面。在本例中，一个标签对应数据云中心，另一个对应其外围。如果至少能找到一个这样的超平面，把两个类别集合彼此分开，就称标签分布可分。进一步地，如果该决策边界是线性的，就称数据线性可分。² 显然，这个玩具数据集在输入空间中并非线性可分。因而，使用简单的线性分类器时，无法找到一条把两个数据类别完全分开的直线。此外，主成分分析等其他线性方法（见章 3）也无法对这些数据作聚类。³

然而，如图 4.1 右图所示，以适当方式变换数据后，数据集就变得线性可分。这里应用变换 $\phi: (x_1, x_2) \mapsto (x_1^2, x_2^2)$ ，把输入数据非线性地映射到所谓的特征空间。因而，映射 ϕ 称为特征映射（feature map）。这里有两点重要注意事项。第一，寻找有用的特征映射是一项高度非平凡的任务。在这个玩具例子中，赋予标签的过程以极坐标考察数据点，并把到原点的径向距离 r 用作标签判据。利用关系 $r^2 = x_1^2 + x_2^2$ ，可以启发我们选择特征映射 ϕ ，但这种选择绝非唯一。第二，即使已经找到良好的特征映射，它也可能是无穷维的。⁴ 在这种情况下，通过特征映射变换数据是不可行的。在本例中，只需对输入变量取平方即可实现线性可分。但在另一些情形中，多项式展开必须进行到无穷阶。在节 4.2.2 末尾回到这个玩具例子时，我们将遇到一个最合适特征空间为无穷维的实例。

幸运的是，许多机器学习算法都可以只用数据点 $\mathbf{x}$ 、 $\mathbf{y}$ 之间的内积表示。^a 因此，无须显式考虑单个输入 $\mathbf{x}$ 及其特征空间表示 $\phi(\mathbf{x})$ 。核技巧只是把相应算法中的内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$ ，替换为函数 $K(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x})^\top \phi(\mathbf{y})$ 。

^a 提醒读者，这些数据点一般都是向量，即它们可能位于高维空间中；另见节 1.5。

² 给定数据集实际上是否（线性）可分并不容易探测。实践中，至少可以运行节 2.4.3 介绍的支持向量机等算法；如果相应的分离超平面存在，这类算法保证能找到它。

³ 如章 3 所述，主成分分析本身并非聚类算法。不过，我们也已经看到，它可以为数据提供一种低维表示，使数据在其中分成不同聚类。

⁴ 从某种意义上说，我们所做的与节 3.2.1 中的主成分分析等降维方法正好相反：通常大幅提高特征空间的维数，以最便利的方式重新排列数据。另一个区别是，把数据嵌入高维空间不会损失其中任何信息。




图 4.1: 带标签的二维玩具数据集. 数据点按照它们相对于分图 (a) 中黑色圆形决策边界的位置赋予标签. 在这一输入空间中, 该数据集并非线性可分. 然而, 把输入变量变换到非线性的特征空间后, 数据变得线性可分, 如分图 (b) 中的黑线所示.

函数 K 可以高效计算; 特别是, 即使 ϕ 映射到无穷维特征空间, 无论所考察的数据或特征空间的维数如何, 它仍给出单个非负实数.⁵ 如下文所示, 函数 K 称为核函数. 通过这种方式, 核技巧为岭回归、支持向量机或主成分分析等多种机器学习算法提供了可行的非线性扩展. 接下来几节将详述核的数学基础.

4.1.2 作为 Hilbert 空间的函数空间

如上所述, 我们希望为特征映射找到合适选择, 也就是搜索位于某个高维函数空间中的函数. 数学空间是由一组元素构成的集合, 这些元素服从规定彼此关系的共同规则. 因为要在函数空间中搜索, 所以合理的做法是假定它是向量空间. 在这类空间中, 可以把函数彼此相加或用常数重缩放, 而不开该函数空间. 要把未知目标函数表示为其他已知函数的加权和, 这一假定必不可少. 幸运的是, 调节权重是机器学习问题中我们已经熟悉的操作.

作为第二项要素, 我们需要某种距离度量, 或者等价地, 需要函数之间的相似性度量. 为此, 给向量空间配备内积 (inner product) $\langle \cdot, \cdot \rangle$, 从而把这个数学空间变成 Hilbert 空间 (Hilbert space). 不同的内积选择会产生不同的距离概念, 也就是产生彼此不同的空间. 很快就会看到为何需要这种相似性度量.

例如, 考虑由实值平方可积函数 (square-integrable function) 构成的空间, 称为 L^2 空间. 配备内积后, 它与更为直观的 Euclidean 空间相似.⁶ 平方可积是指在定义域

⁵在许多情况下, 使用产生无穷维特征空间的核, 反而比使用产生有限维空间的核更容易. 事实上, 有限维性往往可能成为问题. 关于量子核方法及这一问题的相关文献, 见节 8.2.5.

⁶当然, 并非所有希望找到的函数都必然是这个函数空间的成员. 不过, 由于我们面对的总是有限数据集, 通常并不关心远离这一范围处发生的情形. 即使目标函数不是这个空间的成员, 我们仍应能在其中找到一个成员, 使其在所关注区域内近似目标函数. 这正是我们首先可以把讨论限制在 L^2 空间的原因.

D 上的积分保持有限, 即 $\int_D f^2(\mathbf{x}) d\mathbf{x} < \infty$ 对所有 $f \in L^2$ 成立. 在典型机器学习情形中, 定义域 D 对应输入空间, 因而常取为某个维数 m 的 $\mathbb{R}^m$. L^2 空间的内积可以定义为

$$\langle f, g \rangle = \int_D f(\mathbf{x})g(\mathbf{x}) d\mathbf{x}, \quad (4.1)$$

它给出正交的概念 $\langle f, g \rangle = 0$, 以及范数 $\|f\|_{L^2}^2 = \langle f, f \rangle$. 由于 Hilbert 空间是向量空间, 可以找到一组张成该空间的正交基 $\{\phi_n(\mathbf{x})\}$. 对 L^2 空间而言, 它具有无穷但可数无穷的维数. 借助这组基, 任意函数 $f \in L^2$ 都可以分解为

$$f(\mathbf{x}) = \sum_n a_n \phi_n(\mathbf{x}), \quad (4.2)$$

其中 $\{a_n\}$ 是展开系数.

无论两个 Hilbert 空间各自由何种元素构成, 它们都具有相同的几何结构; 正因如此, 我们才能首先在 L^2 空间与直观的 Euclidean 空间之间作类比. Riesz 表示定理 [175] 可以使这一点更加形式化, 其要义如下: 某些线性泛函可以用 Hilbert 空间的内积表示. 我们关注的泛函, 是对 Hilbert 空间 $\mathcal{H}$ 中任意函数 f 在任一点 $\mathbf{x} \in D$ 处作求值 (evaluation), 即 $f \in \mathcal{H} \mapsto f(\mathbf{x}) \in \mathbb{R}$. 一旦试图学习目标函数, 这种求值性质就会变得至关重要. Riesz 定理进一步告诉我们, 存在唯一函数 $K_{\mathbf{x}}$, 使得任意函数 $f \in \mathcal{H}$ 在 $\mathbf{x}$ 处的值, 都可由它同 $K_{\mathbf{x}}$ 的内积求得.

4.1.3 再生核 Hilbert 空间

如前所述, 我们希望利用 Riesz 定理, 把函数空间同其中成员的求值联系起来. 也就是说, 需要 $K_{\mathbf{x}}$ 保证点求值具有如下形式:

$$f(\mathbf{x}) = \langle f, K_{\mathbf{x}} \rangle. \quad (4.3)$$

由式 4.1 并定义 $K_{\mathbf{x}} := K(\mathbf{x}, \cdot)$, 可得到积分变换

$$f(\mathbf{x}) = \int_D K(\mathbf{x}, \mathbf{x}') f(\mathbf{x}') d\mathbf{x}' \quad \forall f \in \mathcal{H}. \quad (4.4)$$

这里, K 充当积分变换的核. 可以看出, 该变换的核 K 必须对称, 即 $K(\cdot, \mathbf{x}) = K(\mathbf{x}, \cdot)$. 此外, 由于 K 在式 4.4 中的作用, 它能忠实再生 Hilbert 空间中的任意函数 f , 所以称为再生核 (reproducing kernel). 如果 Hilbert 空间中每个函数的点求值都可以表示为再生核, 就称该 Hilbert 空间为再生核 Hilbert 空间 (reproducing kernel Hilbert space, RKHS).

我们把 $K(\mathbf{x}, \mathbf{x}')$ 称为核函数 (kernel function). 此外, 以下讨论限于半正定函数 $K(\mathbf{x}, \mathbf{x}')$. 根据 Mercer 定理 [176], 任意对称半正定函数 $K(\mathbf{x}, \mathbf{x}')$ 都可以表示为

$$K(\mathbf{x}, \mathbf{x}') = \sum_n \lambda_n \phi_n(\mathbf{x}) \phi_n(\mathbf{x}'), \quad (4.5)$$

其中系数 $\{\lambda_n\}$ 非负. 此外, 为了在正交归一基下得到满足式 4.4 的 $K(\mathbf{x}, \mathbf{x}')$, 所有系数 λ_n 必须等于 1. 可以任选某个整数 k 并令 $f = \phi_k$ 来证明这一点. 由式 4.4 和核的分解, 必须有

$$\phi_k(\mathbf{x}) = \sum_n \lambda_n \phi_n(\mathbf{x}) \int_D \phi_n(\mathbf{x}') \phi_k(\mathbf{x}') d\mathbf{x}' = \lambda_k \phi_k(\mathbf{x}). \quad (4.6)$$

由于 k 是任意选取的, 当且仅当选择正交归一基时, 才有 $\lambda_n = 1$ 对所有 n 成立. 还可以如下验证, 这种核表示确实实现了式 4.4 中的积分变换:

$$\begin{aligned} \int_D K(\mathbf{x}, \mathbf{x}') f(\mathbf{x}') d\mathbf{x}' &= \sum_{n,k} a_n \phi_k(\mathbf{x}) \int_D \phi_k(\mathbf{x}') \phi_n(\mathbf{x}') d\mathbf{x}' \\ &= \sum_n a_n \phi_n(\mathbf{x}) = f(\mathbf{x}), \end{aligned} \quad (4.7)$$

正如所期望的那样.

可以认出, 当 $\lambda_n = 1$ 对所有 n 成立时, 式 4.5 就是 delta 函数 $\delta(\mathbf{x} - \mathbf{x}')$ 的基组表示. 显然, 这并不是最有用的核函数选择, 因为机器学习任务通常是利用以核函数 $K(\mathbf{x}, \mathbf{x}_i)$ 表示的公式, 在不同于训练点位置 $\mathbf{x}_i$ 的 $\mathbf{x}$ 取值处估计目标函数 $f(\mathbf{x})$. 于是问题变为: 上述论证能否推广到任意对称半正定函数 $K(\mathbf{x}, \mathbf{x}')$? 特别地, 对任意对称半正定核函数, 能否定义一个给出式 4.3 的再生核?

为回答这一问题, 考虑半正定函数 $K(\mathbf{x}, \mathbf{x}')$ 的特征值分解

$$\int_D K(\mathbf{x}, \mathbf{x}') \phi_n(\mathbf{x}') d\mathbf{x}' = \lambda_n \phi_n(\mathbf{x}) \quad \forall n, \quad (4.8)$$

其中 $\lambda_n \geq 0$. 利用式 4.2, 可以把式 4.1 中的内积改写为

$$\begin{aligned} \langle f, g \rangle &= \int_D f(\mathbf{x}) g(\mathbf{x}) d\mathbf{x} = \sum_{m,n} a_m b_n \underbrace{\int_D \phi_m(\mathbf{x}) \phi_n(\mathbf{x}) d\mathbf{x}}_{=\langle \phi_m, \phi_n \rangle = \delta_{m,n}} = \sum_n a_n b_n \\ &= \sum_n \int_D a_m \phi_m(\mathbf{x}) \phi_n(\mathbf{x}) d\mathbf{x} \int_D b_k \phi_k(\mathbf{x}') \phi_n(\mathbf{x}') d\mathbf{x}' \\ &= \sum_n \langle f, \phi_n \rangle \langle g, \phi_n \rangle. \end{aligned} \quad (4.9)$$

然而, 要使 K 成为再生核 Hilbert 空间的有效核函数, 它还必须产生式 4.3. 把这一关系连同 Mercer 分解代入式 4.9 的第一步, 可得

$$\begin{aligned} \langle f, g \rangle &= \int f(\mathbf{x}) g(\mathbf{x}) d\mathbf{x} = \int \langle f, K_{\mathbf{x}} \rangle g(\mathbf{x}) d\mathbf{x} \\ &= \sum_n \lambda_n \int \phi_n(\mathbf{x}) \langle f, \phi_n \rangle g(\mathbf{x}) d\mathbf{x} = \sum_n \lambda_n \langle f, \phi_n \rangle \langle g, \phi_n \rangle. \end{aligned} \quad (4.10)$$

比较式 4.9 与式 4.10, 可以看到二者在前因子 λ_n 上存在差异. 为补偿这一差异, 可以把内积重新定义为

$$\langle f, g \rangle_{\mathcal{H}} = \sum_{n=1}^{\infty} \frac{\langle f, \phi_n \rangle \langle g, \phi_n \rangle}{\lambda_n}, \quad (4.11)$$

当且仅当 $\lambda_n = 1$ 对所有 n 成立时，这一定义才与式 4.1 中的原内积等价。采用这一定义，有

$$\begin{aligned}\langle f, K_{\mathbf{x}} \rangle_{\mathcal{H}} &= \sum_{n=1}^{\infty} \frac{\langle f, \phi_n \rangle \langle K_{\mathbf{x}}, \phi_n \rangle}{\lambda_n} \\ &= \sum_{n=1}^{\infty} \langle f, \phi_n \rangle \phi_n(\mathbf{x}) = f(\mathbf{x}).\end{aligned}\quad (4.12)$$

第二步使用了式 4.8，最后一个等号则来自 $\{\phi_n\}$ 构成完备基这一事实，即式 4.2。这便如期满足了式 4.3，还使 Hilbert 空间 $\mathcal{H}$ 成为再生核 Hilbert 空间，并表明任意二元对称半正定函数 K 确实都是核函数。

需要指出，为每个核函数唯一确定的这一定义至关重要。这正是 Moore–Aronszajn 定理 [177] 的内容。该定理指出，每个再生核 Hilbert 空间都与唯一的半正定核相关联，反之亦然。

4.1.4 表示定理

如果把目标函数表示为基组展开式（式 4.2），那么确定该函数原则上需要求出无穷多个展开系数。然而，在机器学习核方法中发挥核心作用的表示定理（representer theorem）[178]，使我们能够用有限和表示目标函数：

给定一个损失函数 $\mathcal{L}$ （其中包括正则化项）以及 n 个训练样本 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，该定理意味着

$$f^*(\mathbf{x}) := \arg \min_f \mathcal{L}\left(\{(f(\mathbf{x}_i), y_i)\}_{i=1}^n\right) = \sum_{i=1}^n a_i K(\mathbf{x}, \mathbf{x}_i), \quad (4.13)$$

也就是说，使损失最小的函数可以写成核函数的有限和，其中核函数的一个自变量取为训练数据点的位置。此外，只需知道核函数 K ，而无须显式给出特征映射。

表示定理保证，可以把在无穷维函数空间中寻找使特定损失函数最小的函数 f^* ，表述为对 n 个核系数 $\{a_i\}_{i=1}^n$ 的搜索。因而，它显著降低了当前最小化问题的复杂度，使该问题在计算上可处理。

至此，我们在数学上的铺垫终于取得成效：式 4.4 中核的再生性质，使我们可以把输入数据隐式地嵌入一个（可能）高维的特征空间，并在其中计算数据与测试点 $\mathbf{x}$ 的相似性。由于只须计算数据点之间的相似性度量，这里并不会损失效率。下文将在节 4.2 中借助核技巧扩展节 2.4 的若干模型，从而说明如何在实践中实现这一点。

4.1.5 核技巧的推论

我们已经相当详细地讨论了核背后的数学，尤其是与再生核 Hilbert 空间有关的内容。尽管经由 Hilbert 空间并重新定义再生核 Hilbert 空间中的内积，看起来像是绕了一段路，但这些准备工作为核理论奠定了必要基础：式 4.4 中的再生性质并非纯粹的数学奇观，而是通过表示定理带来直接后果。其次，核的表述让我们能够通过辨认适当的

核，解决最初的问题，即高效寻找未知目标函数。核可以理解为表示数据的特征向量之间的相似性度量。即使底层特征空间是高维乃至无穷维的，也可以直接计算输入之间的这种相似性。

借助核技巧从输入空间隐式地切换到特征空间，有一项重要推论：必须重新思考对正则化的直观认识。现在，应当在上一节讨论的、由再生核 Hilbert 空间给出的函数空间中，对所学函数进行正则化。因此，必须从再生核 Hilbert 空间的内积，即式 4.11 出发。系数 λ_n 对应核的基函数权重，并且由构造可知是非负的。特别地，它们依赖于核函数 K 的实际选择。例如，对某些基函数，核的分解中可能含有零系数。这本身并不是问题：我们感兴趣的函数 f 仍可能完全位于再生核 Hilbert 空间中。利用式 4.2，可以把它分解为 $f(\mathbf{x}) = \sum_{n=1}^{\infty} a_n \phi_n(\mathbf{x})$ 。相应的 L^2 范数为 $\|f\|_2^2 = \sum_n |a_n|^2$ 。根据式 4.11，它转化为再生核 Hilbert 空间中的范数

$$\|f\|_{\mathcal{H}}^2 = \sum_{n=1}^{\dim(\text{RKHS})} \frac{|a_n|^2}{\lambda_n}. \quad (4.14)$$

由此可见，当 λ_n 为零时可能会遇到麻烦，因为范数可能发散。当且仅当相应的函数系数 a_n 同时为零时，范数才保持有限。如果函数完全位于与该核函数对应的再生核 Hilbert 空间中，情况正是如此。否则，也就是选择了错误的核函数时，就无法对模型作正则化，也不能期望完整地学到未知目标函数 f 。

再生核 Hilbert 空间理论可以帮助我们直观理解，为何某些核函数选择似乎有效，而另一些却会失败：目标函数 f 必须完全位于由 K 唯一确定的再生核 Hilbert 空间中。否则，学习该函数的方法从一开始就注定失败。我们可以制定构造最优核的策略，也就是为特定问题提供最优的再生核 Hilbert 空间；例如，节 4.4.2 将讨论这种做法。

4.2 核方法

在节 4.1 中，我们介绍了核的数学基础。简言之，希望把数据映射到一个具有更合适当前任务之结构的特征空间。我们不显式定义特征映射 ϕ ，而是引入核函数 K ，由它给出底层特征空间中数据点之间的相似性度量。这样，就把寻找一个（可能）高维特征映射的问题，换成寻找最优核函数的问题；严格说来，后一个问题更容易。这就构成了核技巧。

核方法是利用核技巧的所有分类和回归方法。表示定理保证了这些方法的有效性，见节 4.1.4。每一种核方法的第一步都是选择核函数。如前所述，任意二元对称半正定函数都可以用作核函数。通常先假设某种函数形式（例子见表 1）。这些函数由少数参数作参数化，例如表中所示的 θ ，或 θ_1 与 θ_2 。选定核函数的一种具体函数形式后，再改变这些参数，以便在相应的函数拟设类中找到最佳核。这已经使优化变得更容易，因为现在优化的是一组参数，而不是一组函数。还应注意，给定一组核以后，有许多变换可以产生新的有效核。例如，核函数的任意线性组合 $\sum_i c_i K_i(\mathbf{x}, \mathbf{x}')$ 都构成有效核。更详尽的核构造技术清单见文献 [93]。我们将在节 4.4.2 中明确运用这些规则，讨论如何通过组合式核搜索系统构造良好的核。

表 1: 核函数示例, 其中 θ 、 θ_1 和 θ_2 为自由参数 [135].

核函数	数学形式
线性	$K_{\text{LIN}}(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}' + \theta$
径向基	$K_{\text{RBF}}(\mathbf{x}, \mathbf{x}') = \exp\left[-\frac{1}{2\theta^2}\ \mathbf{x} - \mathbf{x}'\ ^2\right]$
Matérn 5/2	$K_{\text{MAT}}(\mathbf{x}, \mathbf{x}') = \left(1 + \frac{\sqrt{5}}{\theta}\ \mathbf{x} - \mathbf{x}'\ + \frac{5}{3}\ \mathbf{x} - \mathbf{x}'\ ^2\right) \times \exp\left[-\frac{\sqrt{5}}{\theta^2}\ \mathbf{x} - \mathbf{x}'\ \right]$
有理二次	$K_{\text{RQ}}(\mathbf{x}, \mathbf{x}') = \left(1 + \frac{\ \mathbf{x} - \mathbf{x}'\ }{2\theta_1\theta_2^2}\right)^{-\theta_1}$

本小节余下内容转向三种突出的核方法: 核岭回归、支持向量机和高斯过程. 由于我们关注监督核方法, 因此不详细讨论节 3.2 中主成分分析等无监督方法的核扩展 [117, 179].

4.2.1 核岭回归

核岭回归 (kernel ridge regression, KRR) 是岭回归 (见节 2.4.1) 向非线性回归问题的扩展 [180]. 我们希望最小化的泛函与岭回归中的泛函非常相似, 但这一次模型 f 位于由核函数的具体选择所对应的再生核 Hilbert 空间 $\mathcal{H}$ 中 (不过要注意这里使用的是均方误差):

$$\mathcal{L}_{\text{KRR}} = \sum_i^n (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}}^2 = \mathcal{L}_{\text{MSE}} + \mathcal{L}_{\text{reg}}. \quad (4.15)$$

其中的正则化项已在式 4.14 中引入. 这里的 f 不局限于线性函数 (线性岭回归中则受此限制), 原则上可以是任意函数. 因而, 只要选择适当的核, 核岭回归就能构建表达能力很强的模型.

提高机器学习问题的数据效率, 进而在给定固定有限数据集时提高所得模型的准确度, 归结为寻找最优核. 这一点从式 4.15 中并不能立即看出. 为说明核的作用, 回想模型 $f(\mathbf{x})$ 可以写成下面关于训练数据的和:

$$f(\mathbf{x}) = \sum_{j=1}^n \alpha_j K(\mathbf{x}, \mathbf{x}_j). \quad (4.16)$$

这一表述是前述表示定理的一个实例, 见式 4.13. 除了数学形式已知 (或已假定) 的 K , 这里还有核模型 $f(\mathbf{x})$ 的系数 α_j 需要求出. 结合式 4.16, 可以把式 4.15 写成矩阵形式:

$$\mathcal{L}_{\text{MSE}} = \sum_i^n (y_i - f(\mathbf{x}_i))^2 = (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha})^\top (\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}), \quad (4.17)$$

$$\mathcal{L}_{\text{reg}} = \lambda \|f\|_{\mathcal{H}}^2 = \lambda \boldsymbol{\alpha}^\top \mathbf{K} \boldsymbol{\alpha}. \quad (4.18)$$

矩阵 $\mathbf{K}$ 称为核矩阵 (kernel matrix). 它是半正定的 $n \times n$ 方阵, 矩阵元素为 $K(\mathbf{x}, \mathbf{x}')$, 其中训练点 $\mathbf{x}$ 和 $\mathbf{x}'$ 属于训练集 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_n$. 向量 $\mathbf{y}$ 表示相应训练输入 $\mathbf{x}$ 的目标. 最后, 令上述两个分量之和的导数等于零, 就能求得 α 的解:

$$\hat{\alpha} = [\mathbf{K} + \lambda \mathbf{1}]^{-1} \mathbf{y}. \quad (4.19)$$

给定 $\hat{\alpha}$ 后, 模型估计量 $\hat{f}$ 在测试点 $\mathbf{x}^*$ 处可以写为

$$\hat{f}(\mathbf{x}^*) = \mathbf{k}^\top(\mathbf{x}^*) \hat{\alpha} = \mathbf{k}^\top(\mathbf{x}^*) [\mathbf{K} + \lambda \mathbf{1}]^{-1} \mathbf{y}, \quad (4.20)$$

其中 $\mathbf{k}(\mathbf{x}^*) = [k(\mathbf{x}^*)_i] = [K(\mathbf{x}^*, \mathbf{x}_i)]$. [Appendix B](#) 以核岭回归为例, 给出了类似而详尽的核技巧推导. 最后可以看到, 对未见输入 $\mathbf{x}^*$ 的输出预测可以用下列对象表示:

- 目标向量 $\mathbf{y}$;
- 核矩阵 $\mathbf{K}$, 其元素是利用核技巧得到的核函数值 $K(\mathbf{x}_i, \mathbf{x}_j)$;
- 列向量 $\mathbf{k}(\mathbf{x}^*)$, 其元素是同样利用核技巧得到的核函数值 $K(\mathbf{x}^*, \mathbf{x}_i)$;
- 大小为 λ 的正则化项.

正如本章前面所预期的那样, 成功应用核岭回归归结为找到合适的核函数 K , 并调节其相应超参数; 对核岭回归, 这通常通过交叉验证完成. 这应当与下文讨论的高斯过程回归中估计核函数参数的方式作对比.

4.2.2 支持向量机

上一节讨论了如何把核方法用于回归问题, 特别是岭回归. 本节说明如何把它们用于分类. 在这一语境下, 核方法背后的直观认识是: 把输入空间嵌入特征空间, 使数据在其中可由超平面线性分离 (如[节 4.1.1](#) 所述). 利用核技巧最常见的机器学习分类方法是支持向量机 [\[181\]](#).⁷

[节 2.4.3](#) 已经把支持向量机介绍为几何线性分类器. 在考察核如何进入支持向量机之前, 先回顾线性支持向量机的工作方式, 并重新表述[节 2.4.3](#) 中描述的优化问题. 那里的问题是寻找一个分离不同类别数据的最优超平面. 最优超平面定义为同数据点距离最大的超平面. 换言之, 所有数据点到超平面的距离都需要至少为 M . 与超平面的距离恰为 M 、因而最接近超平面的数据点成为支持点 $\mathbf{x}_{s,i}$. 分类问题归结为寻找由 θ 描述的这种超平面, 使超平面与支持点 $\mathbf{x}_{s,i}$ 之间的间隔最大 (见[图 2.5](#)). 由于可以任意重缩放超平面, 可以取 $|\theta| = 1/M$. 于是, 最大化间隔转化为最小化 θ , 后者又归结为最小化[式 2.41](#) 中的 Lagrange 函数 L ; 为便于阅读, 在此重写该式:

$$L = \frac{1}{2} |\theta|^2 - \sum_{i=1}^n \alpha_i [y_i (\theta^\top \mathbf{x}_i + \theta_0) - 1]. \quad (4.21)$$

⁷这种方法有一种为回归设计的变体, 称为支持向量回归 (support vector regression); 它与核岭回归几乎相同, 但最小化的是另一种损失函数.

其中 Lagrange 乘子 α_i 选择为满足

$$\alpha_i [y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0) - 1] = 0 \quad \forall i = 1, \dots, n. \quad (4.22)$$

如前所述，只有对 $\mathbf{x}_{s,i}$, α_i 才非零（且为正）。实践中并不最小化 L ，而是采用问题的对偶表述，最大化为 L 提供下界的 Lagrange 对偶 L_D 。与节 2.4.3 讨论的 L 一样， L_D 仍是二次规划。为用 L_D 表示问题，先分别对 $\boldsymbol{\theta}$ 和 θ_0 求 L 的导数并令其为零，得到

$$\begin{aligned} \boldsymbol{\theta} &= \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \\ 0 &= \sum_{i=1}^n \alpha_i y_i. \end{aligned} \quad (4.23)$$

可以看到，系数 $\boldsymbol{\theta}$ 由 Lagrange 乘子 α_i 给出，而后者可以数值求得。把这些等式代回式 4.21 中的 Lagrange 函数，就得到 Lagrange 对偶：

$$L_D = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \quad \text{约束为 } \alpha_i \geq 0. \quad (4.24)$$

最后，为了把核纳入其中，把 $\mathbf{x}_i^\top \mathbf{x}_j$ 的记号改写为 $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ 。此时支持向量机仍是线性模型。为处理输入空间中的非线性，可以引入特征映射 $\mathbf{x}_i \rightarrow \Phi(\mathbf{x}_i)$ ，于是

$$L_D = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle. \quad (4.25)$$

至此终于出现了核函数 $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle$ 。在这种核表述中，所最大化的是超平面与特征空间中的支持点之间的间隔 [71]。因此，支持向量机问题归结为数值最大化 L_D 以求出系数 α_i ，例如可以使用序列最小优化 [72]。

随后，需要利用留出验证集或交叉验证等方法验证核函数 K 的参数。与神经网络一样，对核参数的每一种试探选择，都必须重新训练支持向量机。两组参数都已知以后，通常为高维空间中分离各类别的超平面也随之确定。借助最优超平面 $\hat{f}$ ，可以在任意测试点 $\mathbf{x}^*$ 处作出预测：

$$\begin{aligned} \hat{f}(\mathbf{x}^*) &= \boldsymbol{\theta}^\top \phi(\mathbf{x}) + \theta_0 = \sum_i \alpha_i y_i \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_i) \rangle + \theta_0 \\ &= \sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + \theta_0. \end{aligned} \quad (4.26)$$

最后，为把这个值转化为类别预测，取 $\hat{f}$ 的符号作为相应类别标签。注意，此处核函数的选择很重要，正如节 4.2 开头所讨论的那样。图 4.2 把这一问题可视化。

我们可以投入大量精力，寻找能使问题线性可分的核函数；也可以允许一些误分类，从而放宽问题。现在转向非线性可分的问题。上述推导依然成立，只须作一项修改：如图 4.3 所示，现在允许一些数据点位于间隔的错误一侧。这会把约束从式 2.40 改为 $y_i(\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0) \geq 1 - \xi_i$ ；若数据点位于间隔的正确一侧，则 $\xi_i = 0$ 。变量 ξ_i 通常称为松




图 4.2: 核的形式确实会带来差异! 使用具有不同核选择的支持向量机, 对图 4.1 中的同一数据进行分类. 黑线分别对应底层决策边界. (a) 数据并非线性可分, 因此线性核不起作用. (b) 最高次数为 50 的多项式核能够完成任务, 但代价是出现过拟合迹象. (c) 由于旋转对称性, 径向基函数核最适合对该数据集作分类, 其决策边界与 (d) 中所示数据的真实底层决策边界非常相似.

弛变量 (slack variable). 为了控制超平面可以“错”到何种程度, 可以加入另一个约束, 即 $\sum_i \xi_i < C = \text{const}$; 这也会给 Lagrange 函数增加相应项:

$$L = \frac{1}{2}|\boldsymbol{\theta}|^2 - \sum_i \alpha_i [y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0) - (1 - \xi_i)] + C \sum_i \xi_i. \quad (4.27)$$

现在, 在最大化间隔的同时最小化对间隔约束的违反. 这一损失函数仍是二次规划, 但优化变量的数量也大幅增加了: 每个数据点都有一个松弛变量. 如前所述, 可以最大化 L_D , 而不是最小化 L . 注意, 在这种情况下会得到一个大小为 C 的附加正则化项. 较大的 C 允许更多数据点被误分类, 但会促进更简单的决策边界. 这是因为, 此时支持向量机专注于用最少数量的相关数据点画出决策边界. 由于相关数据点的数量通常远小于给定训练数据点总数, 所以称之为稀疏解. 相反, 较小的 C 迫使模型更好地拟合训练数




图 4.3: 线性支持向量机应用于一个并非线性可分的数据集. 支持向量机试图最小化所有误分类数据点的总距离 ξ_i , 这些量称为松弛变量. 对误分类的 $\mathbf{x}_i$ (这里 $i = 1, 3, 4$), 有 $\xi_i \geq 1$; 对位于决策边界正确一侧、但处在间隔之内的点 (这里 $i = 2$), 有 $0 < \xi_i < 1$.

据, 有时会以牺牲验证数据上的表现为代价.⁸ 此时, 解的稀疏性较低, 却可能倾向于过拟合训练数据.

最后, 可以在支持向量机与核岭回归之间建立联系. 一开始我们说, 需要在下列条件约束下最小化 $|\boldsymbol{\theta}|^2$:

$$\begin{aligned} y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0) &\geq 1 - \xi_i \quad \text{且 } \xi_i \geq 0, \\ \sum_i \xi_i &< C = \text{const.} \end{aligned} \quad (4.28)$$

如果简单写成

$$\xi_i \geq 1 - y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0), \quad (4.29)$$

并改变 $\boldsymbol{\theta}$ 与 θ_0 以寻找下列函数的最小值:

$$L(\boldsymbol{\theta}, \theta_0) = \frac{1}{2} |\boldsymbol{\theta}|^2 + C \sum_i [1 - y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0)]_+, \quad (4.30)$$

则该问题等价于最小化

$$L(\boldsymbol{\theta}, \theta_0) = \frac{1}{2C} |\boldsymbol{\theta}|^2 + \sum_{i=1}^n [1 - y_i (\boldsymbol{\theta}^\top \mathbf{x}_i + \theta_0)]_+, \quad (4.31)$$

它又等同于

$$L(\boldsymbol{\theta}, \theta_0) = \frac{1}{2} \lambda |\boldsymbol{\theta}|^2 + \sum_{i=1}^n \max[0, 1 - y_i f(\mathbf{x}_i)]. \quad (4.32)$$

⁸应当留意有关正则化强度的多种定义和记号, 支持向量机中尤其如此. 例如, 在 Scikit-learn 中, 减小超参数 C 对应更强的正则化.

最后，把它同式 4.15 中的核岭回归泛函作比较：正则化项相同，主要区别在于核岭回归使用平方误差损失，而支持向量机使用一种称为铰链损失（hinge loss）的函数。这种差异当然源于二者试图解决不同的任务：核岭回归处理回归，支持向量机则处理分类。不过，可以修改支持向量机，使其能够应用于回归任务。在这种情况下，核岭回归的优点是计算效率更高，对小数据集尤其如此。修改后的支持向量机之优点仍是稀疏性，因而可能得到过拟合较少的解。

4.2.3 高斯过程

至此，我们已经介绍了强大而通用的回归工具。我们学习了核技巧，也理解了在特征空间而非输入空间中学习意味着什么。此外，我们还看到这种做法为何有用，尤其是在高维特征空间中，并更深入地考察了一些明确利用核技巧完成良好学习任务的工具。本节再介绍一种工具，即高斯过程。既然我们已经介绍了核岭回归等强大的回归模型，一个自然的问题就是：**为什么还需要另一种回归模型？**简短的回答是，高斯过程回归不仅能做到核岭回归所能做的一切，还能计算预测的贝叶斯不确定性。正如下文将看到的，这一点可用于贝叶斯优化 [182]。在数据非常有限的情形下，高斯过程回归也很适合用于构造与数据高度对齐的核。本节余下内容将说明什么是高斯过程，以及高斯过程回归如何工作。

考虑寻找函数 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ 的回归问题。按照本章的思路，我们希望利用非线性函数 ϕ_i 把输入映射到合适的 d 维空间。然后，如节 2.4.1 所述，应用线性模型，即

$$f(\mathbf{x}) = (\theta_0, \theta_1 \dots \theta_d)^\top (1, \phi_1(\mathbf{x}), \dots, \phi_d(\mathbf{x})). \quad (4.33)$$

这里，每个函数 $\phi_i(\mathbf{x})$ 都是 $\mathbf{x} \in \mathbb{R}^m$ 的某个参数化非线性函数，例如

$$\phi_i(\mathbf{x}) = \tanh \left[w_i \sum_{j=1}^m x_j + b_i \right]. \quad (4.34)$$

式 4.33 可以用图 4.4 中的神经网络来可视化。如果网络的所有权重都固定，网络便把任意给定数据点 $\mathbf{x}$ 映射为单个值 $f(\mathbf{x})$ 。但是，如果现在假设参数 $\theta_0, \dots, \theta_d$ 以及激活函数的超参数 $(w_i, b_i)_i$ 都是服从某种分布的随机变量样本，那么对于固定的 $\mathbf{x}$ ，神经网络的输出本身也成为随机变量。这样的神经网络就成为贝叶斯神经网络（Bayesian neural network）。

这里，神经网络所有可调参数都被提升为随机变量。因而，为了得到例如 $f(\mathbf{x})$ 的期望值及其他类似的关注量，我们必须对参数值取平均。式 4.33 中有 $d+1+2d=3d+1$ 个连续随机变量，即 θ_i, w_i, b_i 。因此，取平均要求我们求解一个 $(3d+1)$ 维积分。这根本不可行；取决于各随机变量所服从的分布，解析求解甚至可能是不可能的。

幸运的是，这个困境有一条出路：假设所有 θ_i 都是独立同分布的随机变量，则在 $d \rightarrow \infty$ 的极限下，中心极限定理⁹会使输出服从正态分布 [183]。由于对于任意给定输入 $\mathbf{x}$ ，该分布始终保持为高斯分布， $f(\mathbf{x})$ 就是我们的第一个高斯过程例子。一般而言，高

⁹中心极限定理指出，许多独立随机变量之和近似服从正态分布。例如，多次掷两枚六面骰子，在投掷次数趋于无穷的极限下，所得点数之和收敛到以七为中心的高斯分布。




图 4.4: 贝叶斯神经网络 (Bayesian neural network) 示意图. 隐藏层中的特征 (蓝色) 乘以式 4.33 所示的随机变量. 这样, 神经网络便不再是确定性的; 给定输入 $\mathbf{x}$ 时, 其输出 $f(\mathbf{x})$ 本身也是随机变量.

斯过程可以视为函数上的正态分布. 它的输出是一个随机变量的实例, 该随机变量服从多元概率密度. 这个初步例子的要点是: 通过在模型中引入随机性, 并假设有无穷多个独立采样的神经网络参数, 模型输出仍保持高斯分布. 与此前分析的模型相比, 这样做的优点是, 随后可以得到对数边际似然和预测分布的闭式表达式.

现在回到我们的问题设定: 希望推断描述给定数据集的函数 f . 数据通常含有噪声. 我们用均值为零、方差为 σ^2 的高斯分布来建模这种数据噪声:

$$y = f(\mathbf{x}) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2). \quad (4.35)$$

为了简单明了, 先只考虑没有任何非线性特征映射的线性模型, 即此时 ϕ 只是恒等映射, 因而式 4.33 化为

$$f(\mathbf{x}) = \boldsymbol{\theta}^\top \mathbf{x}, \quad (4.36)$$

这与节 2.4.1 相似. 同样, 这里包含偏置项, 因此有 $d = m + 1$ 个随机变量.

我们假设每个数据点 $\mathbf{x}_i$ 都与其他数据点相互独立. 对任意给定点, 模型似然写为 $p(\mathbf{y}_i | \boldsymbol{\theta}, \mathbf{x}_i)$. 由于各数据点相互独立, 对于带标签训练数据集 $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, 联合似然为

(另见节 2.3)

$$p(\mathbf{y} | \boldsymbol{\theta}, \mathbf{X}) = \prod_{i=1}^n p(\mathbf{y}_i | \boldsymbol{\theta}, \mathbf{x}_i). \quad (4.37)$$

根据高斯分布噪声的假设 (见式 4.35), 可以把上式右端乘积中的每一项明确改写为

$$p(\mathbf{y}_i | \boldsymbol{\theta}, \mathbf{x}_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(y_i - \boldsymbol{\theta}^T \mathbf{x}_i)^2}{2\sigma^2}\right]. \quad (4.38)$$

因此, 给定数据 $\mathcal{D}$ 后, 模型似然是高斯分布的乘积. 于是, 式 4.37 可以明确改写为

$$\begin{aligned} p(\mathbf{y} | \boldsymbol{\theta}, \mathbf{X}) &= \prod_{i=1}^n p(\mathbf{y}_i | \boldsymbol{\theta}, \mathbf{x}_i) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}|^2}{2\sigma^2}\right]. \end{aligned} \quad (4.39)$$

现在的目标是利用 Bayes 定理计算权重 $\boldsymbol{\theta}$ 上的后验分布 (见节 2.3). 利用式 2.19, 得到

$$p(\boldsymbol{\theta} | \mathbf{y}, \mathbf{X}) = \frac{p(\mathbf{y} | \boldsymbol{\theta}, \mathbf{X})p(\boldsymbol{\theta})}{p(\mathbf{y} | \mathbf{X})}, \quad (4.40)$$

其中 $p(\mathbf{y} | \mathbf{X})$ 是不依赖于 $\boldsymbol{\theta}$ 的归一化常数, $p(\boldsymbol{\theta})$ 表示先验 (仍见节 2.3). 一般而言, 先验可以自由选择. 不过在实践中, 明智地选择先验总会更好. 因此, 应当根据手头问题的先验知识来选择. 例如, 在考虑物理问题时, 可以利用有关系统的背景或先验知识适当地设定先验. 显然, 先验选择得越好, 模型就越有效. 虽然这些是普遍有用的指导原则, 但此处我们完全将其搁置, 并把先验设为

$$\boldsymbol{\theta} \sim \mathcal{N}(0, \boldsymbol{\Sigma}_d), \quad (4.41)$$

它是均值为零、协方差矩阵为 $\boldsymbol{\Sigma}_d$ 的联合正态分布. 特别地, 在参数相互独立的假设下, 可以把 $\boldsymbol{\Sigma}_d$ 选为对角矩阵. 正如下文将论证的那样, 我们甚至可以不失一般性地直接取 $\boldsymbol{\Sigma}_d$ 为单位矩阵, 因为 $\boldsymbol{\Sigma}_d$ 的具体选择 (以及手头问题的任何先验知识) 都可以纳入核的定义. 为先验选择零均值, 可以保证高斯过程的协方差函数确实就是核函数. 更多细节见 Appendix C.

回到后验分布, 可以把所有与 $\boldsymbol{\theta}$ 无关的项归入归一化常数 A , 并利用式 4.37 和 (4.40) 把似然改写为

$$\begin{aligned} p(\boldsymbol{\theta} | \mathbf{y}, \mathbf{X}) &= \frac{p(\mathbf{y} | \boldsymbol{\theta}, \mathbf{X})p(\boldsymbol{\theta})}{p(\mathbf{y} | \mathbf{X})} \\ &= \frac{1}{A} \exp\left[-\frac{|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}|^2}{2\sigma^2}\right] \exp[-\boldsymbol{\theta}^\top \boldsymbol{\Sigma}_d^{-1} \boldsymbol{\theta}]. \end{aligned} \quad (4.42)$$

重新整理指数中的表达式, 后验分布变为

$$p(\boldsymbol{\theta} | \mathbf{y}, \mathbf{X}) = \frac{1}{A} \exp\left[-\frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\mu})^\top \mathbf{C}(\boldsymbol{\theta} - \boldsymbol{\mu})\right], \quad (4.43)$$

其中使用了下列定义：

$$\boldsymbol{\mu} = (\mathbf{X}^\top \mathbf{X} + \sigma^2 \boldsymbol{\Sigma}_d^{-1})^{-1} \mathbf{X}^\top \mathbf{y}, \quad (4.44)$$

$$\mathbf{C}^{-1} = (\mathbf{X}^\top \mathbf{X} + \sigma^2 \boldsymbol{\Sigma}_d^{-1})^{-1}. \quad (4.45)$$

这里， $\boldsymbol{\mu}$ 是后验均值， $\mathbf{C}^{-1}$ 是后验协方差矩阵。¹⁰ 最后，式 4.43 给出了给定数据 $\mathcal{D}$ 后模型参数分布 $p(\boldsymbol{\theta} \mid \mathbf{y}, \mathbf{X})$ 的解析形式。这仍是一个具有更新后均值和协方差的正态分布。从这些新取值的解析形式可见，它们内在地包含了从训练数据推断出的信息。因而， $p(\boldsymbol{\theta} \mid \mathbf{y}, \mathbf{X}) \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{C}^{-1})$ 。

一旦得到了模型参数的更新后分布，下一步就是对先前未见的数据点 $\mathbf{x}^*$ 预测输出 y^* 。为此，需要把后验分布乘以 y^* 的概率，并对所有可能的参数积分。这给出

$$\begin{aligned} p(y^* \mid \mathbf{x}^*) &= \int_{\mathbb{R}^d} p(y^* \mid \mathbf{x}^*, \boldsymbol{\theta}) p(\boldsymbol{\theta} \mid \mathbf{y}, \mathbf{X}) d\boldsymbol{\theta} \\ &\propto \int_{\mathbb{R}^d} \exp\left[-\frac{(y^* - \boldsymbol{\theta}^\top \mathbf{x}^*)^2}{2\sigma^2}\right] \exp\left[-\frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\mu})^\top \mathbf{C}(\boldsymbol{\theta} - \boldsymbol{\mu})\right] d\boldsymbol{\theta}. \end{aligned} \quad (4.46)$$

很容易看出，这个分布仍将是高斯分布。还可以解析计算条件均值和方差：¹¹

$$\hat{\mu} = \mathbf{x}^{*\top} \boldsymbol{\mu} = \mathbf{x}^{*\top} \sigma^{-2} \mathbf{C}^{-1} \mathbf{X}^\top \mathbf{y}, \quad (4.47)$$

$$\hat{\sigma}^2 = \mathbf{x}^{*\top} \mathbf{C}^{-1} \mathbf{x}^*. \quad (4.48)$$

均值可用于作出预测，方差则给出这种估计的不确定性。现在可以把这些结果同此前介绍的方法作比较：

$$\text{线性回归: } \mathbf{x}^{*\top} \hat{\boldsymbol{\theta}} = \mathbf{x}^{*\top} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \quad (4.49)$$

$$\text{线性岭回归: } \mathbf{x}^{*\top} \hat{\boldsymbol{\theta}} = \mathbf{x}^{*\top} (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{1})^{-1} \mathbf{X}^\top \mathbf{y}, \quad (4.50)$$

$$\text{线性高斯过程回归: } \hat{\mu} = \mathbf{x}^{*\top} (\mathbf{X}^\top \mathbf{X} + \sigma^2 \boldsymbol{\Sigma}_d^{-1})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (4.51)$$

以上推导一直针对线性情形，但很容易推广到非线性回归。为此，重新考察上文式 4.33 中的贝叶斯神经网络。在这里，通过 $\mathbf{x} \mapsto \boldsymbol{\phi} = \boldsymbol{\phi}(\mathbf{x})$ ，利用特征映射把输入数据嵌入一个可能很高维的空间。随之有 $\mathbf{X} \mapsto \boldsymbol{\Phi} = \boldsymbol{\phi}(\mathbf{X})$ ，条件均值和方差也可以相应推导。适当地替换各项并作少量数学调整，再采用上文单位方差 $\boldsymbol{\Sigma}_d = \mathbf{1}$ 的简化，就得到

$$\hat{\mu} = \boldsymbol{\phi}^{*\top} \boldsymbol{\Phi}^\top [\boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \sigma^2 \mathbf{1}]^{-1} \mathbf{y}, \quad (4.52)$$

$$\hat{\sigma}^2 = \boldsymbol{\phi}^{*\top} \boldsymbol{\phi}^* - \boldsymbol{\phi}^{*\top} \boldsymbol{\Phi}^\top [\boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \sigma^2 \mathbf{1}]^{-1} \boldsymbol{\Phi} \boldsymbol{\phi}^*. \quad (4.53)$$

这些表达式可以用核函数 K 改写：

$$\hat{\mu} = \mathbf{k}^\top(\mathbf{x}^*) [\mathbf{K} + \sigma^2 \mathbf{1}]^{-1} \mathbf{y}, \quad (4.54)$$

$$\hat{\sigma}^2 = K(\mathbf{x}^*, \mathbf{x}^*) - \mathbf{k}^\top(\mathbf{x}^*) [\mathbf{K} + \sigma^2 \mathbf{1}]^{-1} \mathbf{k}(\mathbf{x}^*), \quad (4.55)$$

¹⁰ 尽管我们从贝叶斯视角得到了这些结果，但地质统计学界在 20 世纪 60 年代就已得到类似结果。在那里，高斯过程回归更常称为克里金法 (kriging) [184]。

¹¹ 其中 $\mathbf{C} = [\sigma^{-2} \mathbf{X}^\top \mathbf{X} + \boldsymbol{\Sigma}_d^{-1}]$ 已在上文定义。

其中使用了下列定义：

$$\phi^{*\top}\phi^* = K(\mathbf{x}^*, \mathbf{x}^*), \quad (4.56)$$

$$(\Phi\phi^*)_i = \mathbf{k}(\mathbf{x}^*)_i = K(\mathbf{x}_i, \mathbf{x}^*), \quad (4.57)$$

$$(\Phi^\top\Phi)_{ij} = \mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j). \quad (4.58)$$

虽然选择 $\Sigma_d = \mathbf{1}$ 可能显得限制得没有必要，但总可以改写上述恒等式以纳入协方差矩阵（例如，式 4.56 变为 $\phi^{*\top}\Sigma_d\phi^* = K(\mathbf{x}^*, \mathbf{x}^*)$ ）。无论如何都要定义核函数，所以选择 $\Sigma_d = \mathbf{1}$ 并不损失一般性。Appendix C 会详细说明，核技巧不会干扰式 4.41 对参数 θ 所作的高斯先验假设。

因此，观察式 4.54 中的条件均值，可以直接看出它与式 4.20 中的核岭回归结果相似，其中正则化强度 λ 对应于由 σ^2 参数化的数据噪声假设。¹² 这并不令人意外，因为式 4.54 中的条件均值对应于节 2.4.1 所介绍的最大后验估计式 2.35。不过，高斯过程回归还给出了预测的不确定性。此外，我们再次看到式 4.13 中表示定理对条件均值 $\hat{\mu}$ 形式的影响，即 $\alpha = (\mathbf{K} + \sigma^2\mathbf{1})^{-1}\mathbf{y}$ 。

4.2.4 训练高斯过程

上一节已经说明了什么是高斯过程、如何构造高斯过程，以及如何用它获得一个（或多个）未见数据点 $\mathbf{x}^*$ 上输出的条件均值和贝叶斯不确定性的闭式表达式。我们知道，高斯过程的性能强烈依赖于先验的选择以及模型接触到的数据量。因此，此时自然会产生一个问题：如何训练高斯过程？首先，需要选择适当的核函数 K ，它相应地定义核矩阵 $\mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$ 。调节该函数的参数（例如表 1 中的参数），目的是最大化所谓的边际似然（marginal likelihood） $p(\mathbf{y} | \mathbf{X})$ 。这一名称源于：该量由 Bayes 定理式 4.40 对模型参数作边际化（即对 θ 积分）而得。此处的目标是用核来表示高斯过程的边际似然。为此，选择高斯过程的协方差矩阵为核矩阵，使得 $\text{Cov}(\mathbf{x}, \mathbf{x}') = \mathbf{K}^{13}$ ；事实证明，这等价于此前的先验选择 $\theta_{\text{prior}} \sim \mathcal{N}(0, \Sigma_d)$ 。Appendix C 给出了相应的数学说明。

最终目标是计算边际似然

$$p(\mathbf{y} | \mathbf{X}) = \int_{\mathbb{R}^d} p(\mathbf{y} | \theta, \mathbf{X})p(\theta | \mathbf{X}) d\theta. \quad (4.59)$$

由于先验的协方差就是核函数，而且被积函数是两个高斯分布的乘积，因此可以用核矩阵 $\mathbf{K}$ 表示 $p(\mathbf{y} | \mathbf{X})$ 。改用边际似然的对数，由 Appendix C 可知，训练过程的目标为

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2}\mathbf{y}^\top (\mathbf{K} + \sigma^2\mathbf{1})^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma^2\mathbf{1}| - \frac{n}{2} \log 2\pi. \quad (4.60)$$

训练高斯过程时，需要寻找使式 4.60 中的对数边际似然最大化的核函数参数。可以看出，训练高斯过程需要核矩阵的逆（并计算其行列式），而该矩阵的维数由训练集大小决定。这已经直观说明了为何高斯过程是少数数据点情形下的首选工具：在这种情况下，它们可以非常有效且成本相对较低。对于含有大量训练数据的问题，高斯过程模型可能很难训练。

¹²这两个常数的差异实际上只源于我们对协方差矩阵的选择。如果改取 $\Sigma_d = \tau^2\mathbf{1}$ ，这种差异就会完全消失，两种方法将给出相同的估计量。

¹³关于记号：显式给出协方差矩阵的输入时使用 Cov ，输入隐含时则只使用 $\mathbf{C}$ 。

算法 5 贝叶斯优化 (BO)

输入: 初始数据集 $\mathcal{D}_0 = \{(\mathbf{X}, \mathbf{y})\}$

输入: 在 $\mathcal{D}_0$ 上训练、均值和方差为 $\hat{\mu}, \hat{\sigma}^2$ 的初始代理模型高斯过程

输入: 待最大化的采集函数

for 迭代 $t < T_{\max}$ **do**

 采样一组候选点 $\mathbf{X}_{\text{cand}}$

▷ 批量优化

$\mathbf{x}^* \leftarrow \max_{\mathbf{x} \in \mathbf{X}_{\text{cand}}} a(\mathbf{x}, \hat{\mu}, \hat{\sigma})$

$y^* \leftarrow f_{\text{BB}}(\mathbf{x}^*)$, 在 $\mathbf{x}^*$ 处

$\mathcal{D} \leftarrow \mathcal{D}_t \cup \{(\mathbf{x}^*, y^*)\}$

▷ 更新数据集

 更新代理模型的参数 $\hat{\mu}$ 和 $\hat{\sigma}^2$

end for

返回 $\hat{\mu}$ 和 $\hat{\sigma}^2$

▷ 代理模型的预测与不确定性

4.3 贝叶斯优化

上一节讨论了高斯过程回归以及如何训练高斯过程. 此外, 我们还说明了, 与核岭回归类似, 高斯过程能够给出测试数据点 $\mathbf{x}^*$ 的输出估计之闭式表达式, 该估计以给定数据集 $\mathcal{D}$ 为条件. 与核岭回归不同, 高斯过程回归还给出了预测不确定性. 这一点意义重大, 因为它可以用于贝叶斯优化 [182].

贝叶斯优化是一种优化昂贵黑箱函数的技术, 适用于梯度难以计算或估计的情形 (例如耗时的实验). 这里, “昂贵”一词非常重要. 事实上, 优化黑箱函数是很大一类机器学习模型和技术的共同目标. 这类优化通常依赖高效计算、任意大量的数据等条件. 然而, 情况并非总是如此. 有时, 问题的可用数据量相当有限, 或者提取额外实验数据的流程非常昂贵. 在这种背景下, 高斯过程与贝叶斯优化的相互配合变得极其重要. 还值得指出, 与目前遇到的大多数机器学习方法 (尤其神经网络) 所用的优化方法不同, 贝叶斯优化是一种无梯度方法. 因此, 它特别适合求值非常困难或昂贵的函数.

在高斯过程回归的语境中, 贝叶斯优化把高斯过程用作待优化黑箱函数的代理模型. 回顾上一节的结果, 高斯过程回归使我们既能得到条件预测, 也能估计其不确定性. 接下来要注意的另一个要点是, 贝叶斯优化是一个迭代过程. 其工作方式如下 (伪代码见算法 5): 贝叶斯优化首先在输入空间的若干随机位置对黑箱函数作少量求值. 将这个初始数据集记为 $\mathcal{D}_0 = \{(\mathbf{X}, \mathbf{y})\}$. 这些求值用于训练高斯过程的第一个版本, 因而可以把它们视为训练数据.¹⁴ 得到第一个代理模型后, 引入所谓的采集函数 (acquisition function). 采集函数通常同时依赖 $\hat{\mu}$ 和 $\hat{\sigma}$, 本质上告诉我们下一次应在何处 $\mathbf{x}$ 求值, 才能使我们从底层黑箱函数获得的知识最大化. 下一小节将说明采集函数的具体形式. 目前, 只需把它看成任意函数 $a(\mathbf{x}, \hat{\mu}, \hat{\sigma})$. 给定一个代理高斯过程先验, 预测及其不确定性便已固定. 因此, 采集函数只依赖新的候选点 $\mathbf{x}$. 现在的目标是寻找信息量尽可能大的候选点. 因而, 下一个求值点通过最大化采集函数确定, 即 $\mathbf{x}^* := \max_{\mathbf{x} \in D} a(\mathbf{x}, \hat{\mu}, \hat{\sigma})$, 其中 D 是 $\mathbf{x}$ 的定义域. 找到新的目标位置 $\mathbf{x}^*$ 后, 下一步是计算黑箱函数, 使得 $y^* = f_{\text{BB}}(\mathbf{x}^*)$. 将求值结果加入高斯过程训练集, 得到 $\mathcal{D} = \mathcal{D}_0 \cup \{(\mathbf{x}^*, y^*)\}$, 再在更新后的 $\mathcal{D}$ 上训练一个

¹⁴由于采用贝叶斯设定, 式 4.35 已经考虑了数据噪声, 所有预测都建立在这一假设之上.




图 4.5: 贝叶斯优化如何应用于高斯过程回归的例子. 高斯过程表示一个在初始观测集 (左上图中的红点) 上训练的代理模型 (浅绿色线). 每一步贝叶斯优化都向先前的观测集加入一个新点, 因此随着加入的点增多, 代理模型越来越确定. 深绿色线表示底层黑箱函数.

不确定性较小的新代理模型. 从这里开始重新迭代: 每次更新代理模型, 都会得到新的预测和不确定性, 从而得到新的采集函数. 因此, 贝叶斯优化的每一步都向 $\mathcal{D}$ 加入一个新点; 整个过程持续到达到最大迭代次数 $T_{\max}$ 或满足某个收敛判据为止. 图 4.5 展示了贝叶斯优化连续三步如何使底层黑箱函数 (深绿色线) 的代理模型越来越确定. 这说明贝叶斯优化可以用于主动学习: 逐步构造训练数据集, 目标是在尽量减少训练点数量的同时, 使其所含信息最大化. 不过, 贝叶斯优化不应与主动学习混淆, 因为二者目的不同. 前者旨在用尽可能少的求值优化目标函数; 后者则试图尽可能高效地采样输入空间, 以得到更准确的预测模型.

贝叶斯优化与高斯过程回归相结合, 相比其他优化方法有以下优点:

- 函数求值次数较少^a;
- 无需梯度.

^a适当选择核可以减少函数调用次数. 此外, 对这种方法而言, 训练集较小更为可取. 式 4.54 表明, 每个试探核都需要核矩阵的逆, 这带来了计算约束.

采集函数

上一小节简要介绍了贝叶斯优化的思想，以及它如何与高斯过程结合作。在这一语境中，我们引入了采集函数。这个量非常重要，因为它是一种在贝叶斯优化流程中引导整个参数空间探索的数学技术。前面已把采集函数定义为 $\mathbf{x}$ 、代理模型预测及其不确定性的一般函数。采集函数有不同种类，其选择大多依赖具体问题。但最重要的是，它的数学形式始终应当包含探索与利用之间的权衡。换言之，采集函数的目标是评估下一个待考察数据位置的有用程度，从而最大化黑箱函数的代理模型，并以更低的不确定性近似目标函数。因而，贝叶斯优化的最终目标是通过最大化采集函数，找到下一个求值点。一个常用且易于解释的例子是置信上界（Upper Confidence Bound, UCB）：

$$a_{\text{UCB}}(\mathbf{x}, \hat{\mu}, \hat{\sigma}) = \hat{\mu}(\mathbf{x}) + \beta \hat{\sigma}(\mathbf{x}). \quad (4.61)$$

其中 $\beta \geq 0$ 是任意参数，理想情况下应在优化流程中调节。此处第一项驱动利用，第二项驱动探索。下文分别把它们称为利用（exploitation）项和探索（exploration）项。

探索项是否在最大化中占主导取决于 β 的取值。观察式 4.61 立即可知，模型会偏好方差较高的新候选点，因为模型奖励对定义域中当前尚未探索区域的求值。这并不奇怪，因为模型试图探索它尚不了解的部分。对均值而言，置信上界偏好较高的均值。这是因为，按照定义，我们寻找的是上界，所以会加强对代理模型上四分位区域的采样。换言之，在 $\beta \gg 0$ 的极端情形下，探索占主导，因而偏好方差较高的区域（见图 4.6 最左图）。

相反，当 $\beta \rightarrow 0$ 时，采集函数变得保守得多，因而会在最佳解周围密集采样，即利用代理模型有信心的区域，如图 4.6 最右图所示。图 4.6 中间图展示了探索与利用之间的良好平衡。因此，对预测均值相近的两个候选点，会优先选择不确定性更高者。其结果是，至少在优化初期，采集函数更偏好探索而不是利用。

此外，考察式 4.54 的解析形式（它作为式 4.61 中的第一项出现）可知，在实践中，采集函数未必总是容易最大化（最小化）。因此，需要利用高效的数值优化流程。由于采集函数高度非凸，实践中采用批量优化（batch optimization）。在贝叶斯优化的每一步，都从给定定义域 D 中随机采样起始点 $\mathbf{x}_{\text{cand}}$ 。然后，从采样点中取最优者（即使采集函数最大者）作为实际候选点。其他广泛使用的重要采集函数例子包括：期望改进（Expected Improvement, EI）、含噪期望改进（Noisy Expected Improvement, NEI）和改进概率（Probability of Improvement, PI）。关于其他采集函数类型更深入而详尽的概述，见文献 [185]。

4.4 选择合适的模型

介绍了强大的核工具箱以后，一个自然的问题随之产生：假设给定一组构成数据集 $\mathcal{D}$ 的“有噪”数据点，以及可能基于两种不同核的两个不同模型 $\mathcal{M}_1$ 和 $\mathcal{M}_2$ ，应当选择哪一个？这正是模型选择（model selection）背后的核心问题。为回答这个问题，再次采用贝叶斯方法（见节 2.3）。对每个模型 $\mathcal{M}_i$ 应用式 2.19 中的 Bayes 定理，得到

$$p(\mathcal{M}_i | \mathcal{D}) = \frac{p(\mathcal{D} | \mathcal{M}_i)p(\mathcal{M}_i)}{p(\mathcal{D})}. \quad (4.62)$$




图 4.6: 采用置信上界采集函数, 通过贝叶斯优化选择新候选点. 蓝色虚线表示目标函数. 橙色实线是代理模型 (高斯过程), 橙色阴影表示其不确定性. 最左图表现出利用行为, 即大多数选定点位于峰附近. 与之相反, 最右图中的 β 参数选择强烈促进探索. 因此, 新采样点 (红点) 均匀分布在定义域的一部分中 (例如, $x \sim 2$ 附近还需要更多利用). 中间图展示探索与利用之间的权衡: 采样候选点在整个定义域内分布良好, 因而即使在峰和边界附近也能高效近似目标函数.

合并两个模型的表达式, 得到

$$\frac{p(\mathcal{M}_1 | \mathcal{D})}{p(\mathcal{M}_2 | \mathcal{D})} = \frac{p(\mathcal{D} | \mathcal{M}_1) p(\mathcal{M}_1)}{p(\mathcal{D} | \mathcal{M}_2) p(\mathcal{M}_2)}. \quad (4.63)$$

如果对模型性能没有先验知识, 就必须把两个模型的先验设为相同. 在这种情况下, 后验概率之比 $P(\mathcal{M}_i | \mathcal{D})$ 等于先验概率之比 $P(\mathcal{M}_i)$ 乘以所谓的贝叶斯因子 (Bayes factor)

$$\frac{p(\mathcal{D} | \mathcal{M}_1)}{p(\mathcal{D} | \mathcal{M}_2)}. \quad (4.64)$$

式 4.63 给出了问题的第一个答案: 在贝叶斯框架中, 可以利用后验概率之比, 判断在给定手头数据时哪个模型更优; 也就是说, 后验概率较大的模型更优. 在完全不了解数据的情形下, 可以令两个先验概率相等, 此时只剩下贝叶斯因子

$$\frac{p(\mathcal{M}_1 | \mathcal{D})}{p(\mathcal{M}_2 | \mathcal{D})} = \frac{p(\mathcal{D} | \mathcal{M}_1)}{p(\mathcal{D} | \mathcal{M}_2)}. \quad (4.65)$$

为了计算式 4.64 中的贝叶斯因子, 需要对每个模型计算 $p(\mathcal{D} | \mathcal{M}_i)$; 它可以视为边际似然, 即除模型类型外所有变量均已作边际化 (积分消去) 的似然函数. 把似然定义为 $p(\mathcal{D} | \theta, \mathcal{M}_i)$, 则边际似然为

$$p(\mathcal{D} | \mathcal{M}_i) = \int_{\mathbb{R}^d} p(\mathcal{D} | \theta, \mathcal{M}_i) p(\theta | \mathcal{M}_i) d\theta, \quad (4.66)$$

其中对 $p(\theta | \mathcal{M}_i)$ 给出的模型参数分布 $\theta \in \mathbb{R}^d$ 积分. 遗憾的是, 边际似然通常很难计算, 因为它们涉及高维积分. 选择具有 d 个参数的核, 会使其边际似然包含一个 d 维积分.

遇到这个问题后，不妨退一步思考：训练模型时，要最小化损失函数（或等价地最大化对数似然）。那么，为什么不直接选择损失最低或似然最大的模型？直观上，这会导致过拟合。偏差—方差权衡把这种直觉形式化了（见节 2.2）。特别地，偏差—方差权衡清楚表明，理想模型在训练误差和模型复杂度之间达到最优平衡。因此，不能选择训练期间损失最低的模型，而必须把模型复杂度考虑在内。

4.4.1 贝叶斯信息准则

一种计算上可行、并把模型复杂度纳入考虑的模型选择准则是贝叶斯信息准则 (Bayesian information criterion, BIC) [186]，其定义为

$$\text{BIC} = -2 \max(\ell) + d \log(n), \quad (4.67)$$

其中 $\max(\ell)$ 是对数似然的最大值， n 是训练点数量， d 是模型参数数量。贝叶斯信息准则越低，模型越好。显然，该准则反映了偏差与模型复杂度之间的权衡；此处前者由 $\max(\ell)$ 给出，后者由 $d \log(n)$ 度量。此外，事实证明，在 n 很大的极限下，贝叶斯信息准则近似边际似然的对数 [187]：

$$\log p(\mathcal{D} \mid \mathcal{M}_i) \approx \log p(\mathcal{D} \mid \boldsymbol{\theta}^*, \mathcal{M}_i) - \frac{d}{2} \log(n), \quad (4.68)$$

其中 $\boldsymbol{\theta}^*$ 是使似然最大化的模型参数。这个表达式揭示，式 4.63 基于贝叶斯方法给出的模型选择准则确实考虑了模型复杂度。此外，该准则还可用于估计模型 $\mathcal{M}_i$ 的后验概率：

$$p_i = \frac{\exp(-\frac{1}{2} \text{BIC}_i)}{\mathcal{N}}. \quad (4.69)$$

这里，归一化常数 $\mathcal{N} = \sum_i e^{-\text{BIC}_i/2}$ 保证每个模型 $\mathcal{M}_i$ 都被赋予有效概率 p_i ，从而可以相互比较。因此，贝叶斯信息准则为按照式 4.63 中的准则选择模型提供了一种计算上可行的方式。事实上，作为模型选择度量，贝叶斯信息准则具有渐近相合性 (asymptotic consistency)：给定一个包含生成数据之真实模型的模型族，当 $n \rightarrow \infty$ 时，贝叶斯信息准则正确选中真实模型的概率趋于 1。¹⁵

受这些结果启发，可以根据训练期间（核参数固定时）优化的对数边际似然以及高斯过程回归中的核参数数量，把这一准则适配到高斯过程回归。该准则在计算上可行，因而可以在使用高斯过程的回归任务中选择不同的核。

4.4.2 核搜索

使用基于核的方法时，选择合适的核至关重要；例如，图 4.2 已经展示不同核对支持向量机性能的影响。以朴素 (naive) 方式进行高斯过程回归时，只需从表 1 所列的常

¹⁵尽管贝叶斯信息准则在 n 很大的极限下近似对数边际似然，它仍可在 n 较小时用作启发式模型选择准则，而且经验上常能确认它仍给出良好结果。还有许多其他模型选择准则（综述见文献 [187]），其中一个常用准则是与贝叶斯信息准则非常相似的 Akaike 信息准则 (Akaike information criterion) [188]。贝叶斯信息准则与许多其他方法的关键区别是其渐近相合性。由于实际候选模型集合通常不包含真实模型，人们可能会质疑渐近相合性的重要程度。




图 4.7: 高斯过程回归中最优核构造算法背后的搜索树示意图. 它采用式 4.67 所介绍的贝叶斯信息准则作模型选择. 可能的核函数及相应缩写概览见表 1. 改编自文献 [135].

规核集合中选择一个固定核, 再通过最大化训练期间的边际似然来优化其超参数. 要得到更准确的模型, 有几条可能路径. 显然, 提供更多训练点可以提高模型准确度. 然而, 与其他方法相比, 保持训练点数量较少正是高斯过程回归的主要优点之一, 也是最初的主要动机. 在训练数据量固定时, 只能通过更好的核改进高斯过程回归结果. 此外, 虽然贝叶斯优化保证收敛, 但确切迭代次数可能相差很大. 选择良好的核可以显著加快贝叶斯优化收敛.

构造良好的核最终归结为一个 (可能高维的) 优化问题 [189]. 例如, 通过优化核超参数本身来构造良好核时就是如此. 关键挑战在于, 核的参数形式必须由用户自己提出. 即使对专家而言, 这也是一项依赖反复试错的非平凡任务. 文献 [190, 189, 135] 把核学习问题重述为搜索树问题 (见图 4.7): 核的参数形式空间被构造成一棵树, 可以自动、系统地搜索; 其中用强大的贝叶斯信息准则选择核, 并通过复合提出新核.

首先, 从常规核集合中逐个选择核, 并在同一数据集上为每个核训练一个高斯过程. 然后, 按照式 4.67 选择贝叶斯信息准则值最低者 (图中以蓝色突出). 这个核作为下一轮的基础核, 与初始集合中的各个核相结合, 通过求积或线性组合构造新的候选核. 再次按照贝叶斯信息准则选出最佳核, 并重复这一过程. 随着在搜索树中不断深入, 模型——即复合核——的复杂度会增加. 最终, 进一步提高核复杂度会导致过拟合, 因而无法相对上一轮的核改进贝叶斯信息准则值, 此时算法停止. 如果核参数数量变得很大、相应训练耗时过长而不再实用, 算法也可以提前停止. 除贪心搜索这棵树之外, 把核构造重述为搜索树问题还开启了采用更高级策略的可能性, 这些策略可以更高效地得到更好的核 [191, 192].

4.5 量子科学中的应用

前几节已说明, 高斯过程和贝叶斯优化是两种强大方法, 二者结合可以构建富有表达力的机器学习模型. 重要的是, 它们自带对不确定性的内禀度量, 并且可以用少量训练数据训练. 本节讨论这两种方法如何用于量子科学, 如图 4.8 所示. 特别地, 高斯过




图 4.8: 量子科学中已由贝叶斯优化和高斯过程成功处理的三类主要问题（黄色标示）示意图。

程和贝叶斯优化可用于处理逆问题（inverse problem）、在 Hamiltonian 参数空间中 extrapolation，以及提高量子动力学计算的准确度。

4.5.1 逆问题

如节 4.3 所述，当需要优化求值代价高昂的黑箱函数时，贝叶斯优化非常有用。这一性质在量子逆问题中特别有价值：此类问题通过实验测量系统的可观测量，力图找出系统的理论描述。其思想与一种称为最优控制（optimal control）的常用实验方法有关。最优控制旨在设计能够产生所需量子动力学的外场参数。它通常通过反馈回路实现：迭代修改实验参数，使其产生的系统动力学不断趋近目标动力学。

可以设想把类似的反馈回路用于量子逆问题。其中不断迭代理论描述的参数（如 Hamiltonian 参数），直至理论预测的可观测量与实验测量结果相符。然而，求解这种迭代逆问题颇具挑战。每次迭代都需要再进行一次理论计算，例如数值求解 Schrödinger 方程，十分耗时。优化本身也很困难，因为需要探索的参数范围并不明确。最后，Hilbert 空间维数随量子系统复杂度指数增长的诅咒显然更令问题雪上加霜。如何使它更可行？如果用训练好的代理机器学习模型（如高斯过程）替代代价高昂的黑箱——无论是实验装置还是理论计算——量子逆问题与最优控制都会变得更容易。最后，还可以采用贝叶斯优化，而不必盲目搜索最优参数。




图 4.9: 采用贝叶斯优化和高斯过程后, 优化变得可行的反馈回路示例. (a) $\mathbf{x}$ 对应势能面, $f(\mathbf{x})$ 是以势能面为输入的量子散射计算, T 是由 $f(\mathbf{x})$ 计算的反应概率与实验在不同碰撞能量下测得反应概率之差. 搜索最优 $\mathbf{x}$ 需要通过优化 $f(\mathbf{x})$ 来最小化 T . 用一个高斯过程代理 $f(\mathbf{x})$ 、另一个高斯过程代理 $\mathbf{x}$, 再应用贝叶斯优化, 问题便变得可行. (b) $\mathbf{x}$ 是 Hamiltonian 参数, $f(\mathbf{x}, t)$ 是含时可观测量 f (例如分子取向或排列), $\mathcal{F}(\mathbf{x})$ 是含时 Schrödinger 方程, T 是计算与测量得到的含时可观测量 f 之差. 用高斯过程代理 $\mathcal{F}(\mathbf{x})$ 后, 利用贝叶斯优化最小化 T , 并找出底层 Hamiltonian 的 $\mathbf{x}$.

作为用贝叶斯优化和高斯过程求解逆问题的实际例子, 考虑它们在散射实验 (scattering experiment) 中的应用. 这类实验的结果由散射粒子之间的微观相互作用决定. 我们已有描述这些相互作用并可预测散射事件结果的量子理论. 因而, 在逆问题中, 目标可以是从实验推断这些微观相互作用. 更具体地说, 文献 [194] 的作者力图只用尽可能少的反应速率实验测量 (反应速率取决于组分的平动能), 恢复支配化学反应 $\text{H} + \text{H}_2 \longrightarrow \text{H}_2 + \text{H}$ 的全局势能面 (potential energy surface, PES).¹⁶ 需要求解的反馈回路见图 4.9(a). 首先, 他们在一系列势能面及所预测的反应速率上训练一个高斯过程, 以代理量子散射理论. 其次, 他们用另一个高斯过程为势能面建模. 最后, 他们利用贝叶斯优化找到三维势能面, 从而恢复测得的反应速率. 贝叶斯优化只需八次迭代 (每次迭代都完全重建势能面), 就达到了常规方法的准确度! 而且, 在这个例子中, 构建势能面的传统方法需要约 8700 个点, 他们的高斯过程模型却只基于 30 个点!¹⁷ 这种惊人的缩放见图 4.10. 结果是, 他们用两个高斯过程成功代理了两个复杂模型 (势能面, 以及以势能面为输入的量子散射计算), 而训练数据点数远少于构建原复杂模型所需的数量. 他们还把这一方法用于 $\text{OH} + \text{H}_2$ 的六维势能面; 贝叶斯优化用 290 个点就胜过了需要 17000 个点的传统方法.¹⁸

¹⁶ 势能面描述若干粒子之间的相互作用. 因而, 它为化学反应的景观建模, 可用于预测反应路径和最终产物. 传统上, 势能面是对许多通常代价高昂的从头算 (ab initio) 量子化学计算作解析拟合而构成的; 这些计算给出反应物处于不同相对位置时的势能.

¹⁷ 请记住, 这并非任意 30 个点, 而是贝叶斯优化指出的、为得到最优描述所需的点.

¹⁸ 高效贝叶斯优化所需的点数大致按势能面维数的 10 倍缩放. 这里可以提出一个有趣的问题: 如果只根据反应概率构建势能面, 如何确信忠实复现了它? 我们可能准确捕捉了反应化学通道, 但曲面的其余部分没有约束, 因而可能不符合物理. 可以主张, 我们归根结底不需要完整、忠实地复现底层势能面, 只需要一个能够准确预测所关注对象——这里是反应概率——的势能面. 不过请注意, 如果用根据一组特定可




图 4.10: (a) 反应 $H_2 + H \longrightarrow H + H_2$ 的反应概率随碰撞能量的变化. 黑色实线表示文献 [193] 基于包含 8701 个从头算 (*ab initio*) 点的曲面所作计算. 蓝色、橙色、绿色和红色虚线分别表示基于由 22、23、30 和 37 个从头算点得到的高斯过程势能面所作计算. (b) 用 30 个从头算点构建的 H_3 反应体系势能面高斯过程模型. R_1 和 R_2 分别是原子 1 与 2、原子 2 与 3 之间的距离. 改编自文献 [194].

量子逆问题的另一个例子，是由含时可观测量推断分子性质. 文献 [195] 的作者根据强激光脉冲诱导的 SO_3 和环氧丙烷取向或排列信号的时间演化，重建分子极化率张量. 所求解的反馈回路绘于图 4.9(b). 他们使用具有向量输出的高斯过程；每个输出分量对应于在一个不同时间步对选定可观测量（取向或排列）的预测. 在给定 Hamiltonian 参数时，该高斯过程被训练来代理含时 Schrödinger 方程的数值积分. 有趣的是，作者展示了我们已在节 4.4 中讨论的现象：恰当选择核可以使贝叶斯优化的收敛速度提高一倍. 类似方法还被用于根据分子超精细实验重建分子散射矩阵 [196]，以及优化有机化学实验的反应条件 [197].

4.5.2 改进量子动力学、物理模型与实验

高斯过程和贝叶斯优化还可用于量子动力学计算语境中的迁移学习 (transfer learning). 这类计算通常非常困难，很快就不得不依赖近似. 文献 [198] 的作者提出用高斯过程修正计算分子碰撞截面时采用的近似量子计算. 其思想是，用少量精确结果和大量近似计算训练模型，得到能够把精确量子结果泛化至不同动力学过程的机器学习模型.

此外，由于利用贝叶斯优化最小化任意函数都无需计算梯度 [182]，贝叶斯优化的成功应用包括优化物理模型的参数. 大多数模型没有闭式解，传统上必须用有限差分作数值近似. 例如，文献 [199, 200] 表明，贝叶斯优化可以高效优化密度泛函模型以提高其准确度，并最小化 Ising 模型的能量 [201]. 此外，贝叶斯优化还被用于生成低能分子构象 [202, 203]，调节模拟视紫红质中视黄醛顺—反异构化所用的各种模型参数 [204]，以及优化激光器 [205, 206, 207]. 在材料科学中，贝叶斯优化也对化合物筛选 [208, 209, 210, 211, 212, 213] 和实验装置优化 [214, 215, 216, 217, 218, 219] 产生了

可观测量构建的势能面计算另一种可观测量，结果可能是错误的.

重要影响.

4.5.3 外推问题

第二类适合高斯过程的问题是外推 (extrapolation) 任务: 给定一个区域内若干数据点处的函数值, 目标是准确预测其他区域中数据点的函数值. 本节涉及两种可能应用: (1) 用某一区域内尽可能少的从头算计算学习势能面; (2) 在不了解完整相图的情况下预测量子相是否存在.

势能面学习中一个成功的外推例子见文献 [191], 作者研究了 H_3O^+ 的六维势能面. 他们用低能区 (最高约 7000 cm^{-1}) 的 1000 个从头算几何构型训练高斯过程模型, 并核实模型在更高能区的预测与完整计算高度准确地吻合. 若对此有所怀疑, 可以利用已发布的代码和数据复现这一结果 [2]. 还有更好的结果! 即使面对含 19 个原子的质子化咪唑二聚体这一 51 维问题, 也只需 5000 个分子几何构型训练高斯过程模型, 就能得到精度相近的外推 [220]. 对大分子而言, 外推准确度随训练点数的缩放似乎还要有利: 只用随机采样的 1000 个 57 维阿司匹林几何构型, 就已达到很高准确度.¹⁹

另一个外推例子发生在 Hamiltonian 空间: 已知系统一个特定相的信息, 推断其其他相的性质. 文献 [135] 的作者提出在系统的一个相上训练高斯过程, 并期望模型预测相变和其他相的性质. 先讨论他们如何在最近邻近下的平均场 Heisenberg 自旋模型中实现这一点. 他们用高温区的系统自由能训练高斯过程; 在这个远离相变点的区域, 平均自旋磁化为零. 随后让训练好的高斯过程外推低温区; 如图 4.11(a) 所示, 它同时正确预测了相变位置以及系统的自由能 (从而也预测了非零磁化).




图 4.11: 用高斯过程外推未见过的量子相. (a) 最近邻近似下的平均场 Heisenberg 自旋模型, 其中黑点为平均场结果, 蓝点为高斯过程预测. 高斯过程在数据的高温阴影区域上训练. (b)–(c) 采用不同高斯过程训练区域 (白点标示) 的广义晶格极化子模型. 与量子计算 (黑线) 相比, 两种情形下高斯过程都正确预测了相变 (色图). 改编自文献 [135].

¹⁹更确切地说, 测试能量的平均绝对误差为 0.177 kcal/mol . 这个误差小吗? 这些势能面足以满足现代光谱学应用吗? 光谱学区分两种准确度: 光谱准确度为 1 cm^{-1} , 化学准确度为 $1\text{ kcal/mol} \approx 350\text{ cm}^{-1}$. 现代光谱学应用需要光谱准确度, 而这一结果的误差是光谱准确度的 60 倍——所以, 还不够好. 但例如对于分子动力学或反应模拟, 尤其是在室温下, 它已经绰绰有余 [221].

作者还把这一方法应用到复杂得多的系统，²⁰其 Hamiltonian 可写成如下通用形式：

$$H = H_0 + \alpha H_1 + \beta H_2, \quad (4.70)$$

其中 α 和 β 是沿其变化会发生相变的可调参数。他们在 Hamiltonian 的某个参数区域中训练高斯过程，并成功外推到其他区域。²¹这一方法对这类 Hamiltonian 还有另一个用处。通常，我们可以在 α 和 β 的某些极限下轻易计算或测量本征谱，却无法在参数空间中的任意点做到这一点。因而，可以在这些极限下训练高斯过程，并期待它们成功外推到直接计算更困难的其他参数区域。最后，文献 [194] 的作者还在同一系统中研究了选择核的重要性。他们把原工作 [135] 中按节 4.4.1 和节 4.4.2 所述用贝叶斯信息准则找到的核，与复杂度相同（即处于同一搜索树层级，见图 4.7）但随机选取的核进行比较。后一种高斯过程的预测差得多，也容易过拟合，这凸显了贝叶斯信息准则作为核选择准则的威力。因而，恰当选择核至关重要，因为它决定模型能够准确外推多远。

4.5.4 变分量子算法的贝叶斯优化

贝叶斯优化的另一项合适应用属于近期量子计算语境：人们力图利用含噪中等规模量子（noisy intermediate-scale quantum, NISQ）设备获得计算优势，另见节 8.2.4。一种常用策略是变分量子本征求解器（variational quantum eigensolver, VQE）。这类算法是用于寻找给定 Hamiltonian 基态的量子—经典混合算法。变分量子本征求解器已应用于多个领域，例如见文献 [223, 224, 225, 226, 227]。在这些算法中，参数优化在经典计算机上进行。把量子线路视作参数化黑箱后，贝叶斯优化自然成为一种无梯度优化工具。

近期工作已证明，贝叶斯优化在优化变分量子本征求解器时具有资源效率 [228, 229, 230]，这里的资源指量子算法的调用次数。特别地，文献 [230] 表明，核方法是这项任务的自然选择，因为可以把物理先验知识直接纳入核本身。为此，作者推导出一种新的通用核，其函数形式与希望用贝叶斯优化最小化的目标黑箱函数相同。因而，对变分量子线路参数的优化可借助已有的线路先验知识。此外，作者还引入了一种新型采集函数。该采集函数的关键特征是：依据模型对当前参数选择的置信程度，寻找下一个测量点。如果高斯过程对某个候选点置信度高，即方差较小，该点就很可能被跳过。因此，借助序列最小优化方案 [231, 232]，即依次逐个优化参数，这种新采集函数能更好地收敛到全局最优解。文献 [230] 所示结果表明，其中提出的新优化方案能够超越（写作本书时的）最新方法 [231]。

尽管文献 [230] 中的核是在寻找给定 Hamiltonian 基态的语境中提出的，但它可与任何其他采集函数结合，用于任何其他优化任务。类似地，这种新采集函数与上述核结合后，也构成适用于其他任何优化任务的通用框架。

²⁰所研究的系统是一个广义晶格极化子模型 [222]，描述一维 $N \rightarrow \infty$ 个格点的晶格中与声子场耦合的电子。电子与声子场的相互作用是两个定性不同的项之组合：Su-Schrieffer-Heeger (SSH) 电子—声子耦合，以及具有 Holstein 耦合的呼吸模模型。

²¹这怎么可能？其背后的直觉是，作为输入提供给机器学习模型的物理性质演化，应当以某种方式反映相变的存在。模型可能捕捉到一个相内占主导的关联，并观察到跨越其他相时这些关联发生变化。

4.6 展望与开放问题

- 高斯过程虽能成功代理势能面，所需从头算计算数量也少得多，但用这种方法达到光谱准确度仍很困难。是什么阻碍高斯过程达到这样的准确度？主要限制在于训练数据量。实践中常观察到，学习期间的误差最终按 $1/n$ 的因子下降，其中 n 是训练点数。因而，对 57 维曲面达到约 10 cm^{-1} 的准确度，所需训练点数仍可控制。然而，要达到光谱准确度，就需要过量训练数据。特别地，训练数据集的规模会增长到高斯过程不再适用的区域 [233]。若把关于系统的某些知识纳入核，或许可以达到高准确度极限。如何做到这一点，仍是一个有待回答的开放问题。
- 在节 4.5 中，我们已经介绍了如何用贝叶斯优化和高斯过程处理无法获得梯度的昂贵装置优化。量子神经网络或变分自编码器也属于这种情形。因而，这一方法或许能用于优化量子模型！
- 一个有趣的研究方向，是把节 7.1 所述自动微分的威力与核方法结合。自动微分已经在为高斯过程模型开发更稳健的核函数方面发挥了重要作用。例如，文献 [234] 表明，通过最大化对数边际似然（式 4.60），可以联合优化深度神经网络的权重和偏置，以及标准核函数的任意参数。较新的工作 [235] 还表明，在自动微分框架下，学习核的复合是可微的，因而可以参数化更复杂的核。目前，基于自动微分的高斯过程主要有两个生态系统：GPytorch [236, 237] 和 GPflow [238]。
- 核岭回归的训练过程也可以用自动微分求导，从而无须采用交叉验证方案 [239]。
- 随着面向近期量子设备的经典机器学习方法之量子扩展出现，把数据点 $\mathbf{x}$ 编码进 Hilbert 空间成为 $|\mathbf{x}\rangle$ 有了多种途径。因而，核函数也必须提升为其量子核 (quantum kernel) 版本。有趣的是，基于量子态测量结果的这类核具有可证明的优势 [240]。节 8.2 将给出更多细节。

延伸阅读

1. Rasmussen, C. E. & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press. 核方法、特别是高斯过程领域的标准首选参考书 [241]。
2. Bishop, C. M. (2006). *Machine Learning and Pattern Recognition*. 另一部高斯过程领域的首选参考书 [93]。
3. Krems, R. V. (2019). *Bayesian machine learning for quantum molecular dynamics*. *PCCP* 21(25), 13392–13410. 讨论高斯过程在量子分子动力学中的多种应用 [242]。
4. 一个 [Jupyter notebook](#)，用高斯过程和贝叶斯优化忠实复现 H_3O^+ 的六维势能面，其中包括依据贝叶斯信息准则进行最优核搜索 [2]。
5. Vargas-Hernández, R. A. & Krems, R. V. (2020). *Physical extrapolation of quantum observables by generalization with Gaussian processes*. *Lect. Notes Phys.* 968, 171–194. 深入综述高斯过程和贝叶斯优化在量子科学外推问题中的可能应用 [243]。
6. Huang, H. et al. (2021). *Provably efficient machine learning for quantum many-body problems*. *Science* 377(6613). 该文引入量子测量启发的核，并证明核方法相对不使用测量数据的经典方法具有优势 [244]。

神经网络量子态

在量子力学发展的早期，人们很快就认识到，要解决大多数重要的现实问题，必须采用近似方法 [245]。事实上，在多数情况下，只要体系包含多于少数几个相互作用粒子，Schrödinger 方程就无法精确求解。这后来被称为量子多体问题（quantum many-body problem）。本章将说明神经网络如何被引入来处理这一问题 [246]，其应用包括相互作用量子体系的基态与量子动力学。为简化讨论，我们主要关注自旋体系，只在接近末尾时讨论对费米子 [247] 和玻色子 [248] 的应用。

按照量子力学公理，孤立量子体系的状态编码在一个复值概率振幅向量中，通常称为波函数。对单个自旋- $\frac{1}{2}$ ，在计算 z 基 $\hat{Z}$ 中，波函数为 $|\Psi\rangle = C_\uparrow|\uparrow\rangle + C_\downarrow|\downarrow\rangle$ 。系数 $C_\uparrow$ 和 $C_\downarrow$ 是自旋沿计算基方向排列 ($C_\uparrow$) 或与该方向相反 ($C_\downarrow$) 的复概率振幅，并满足归一化条件 $|C_\uparrow|^2 + |C_\downarrow|^2 = 1$ 。对含 N 个自旋的多体量子体系， N 可以从几十到 Avogadro 数量级 $\sim 10^{23}$ 的任意大数，波函数中的系数数目按 2^N 标度。沿用自旋的例子，波函数可表示为

$$\begin{aligned} |\Psi\rangle &= C_{\uparrow\uparrow\cdots\uparrow}|\uparrow\uparrow\cdots\uparrow\rangle + C_{\uparrow\uparrow\cdots\downarrow}|\uparrow\uparrow\cdots\downarrow\rangle + \cdots + C_{\downarrow\downarrow\cdots\downarrow}|\downarrow\downarrow\cdots\downarrow\rangle \\ &= \sum_{\sigma_1, \sigma_2, \dots, \sigma_N} C_{\sigma_1, \sigma_2, \dots, \sigma_N} |\sigma_1\rangle \otimes |\sigma_2\rangle \otimes \cdots \otimes |\sigma_N\rangle. \end{aligned} \quad (5.1)$$

这里， $|s\rangle = |\sigma_1\rangle \otimes |\sigma_2\rangle \otimes \cdots \otimes |\sigma_N\rangle$ 是描述 N 自旋体系的 Hilbert 空间基向量， $C_{\sigma_1, \sigma_2, \dots, \sigma_N}$ 是与之对应的振幅。

量子多体问题源于基元素数目的指数标度，它导致计算复杂度随体系大小指数增长。特别地，仅以朴素方式存储 60 个自旋的波函数，就需要 $16 \cdot 2^{60} \approx 18$ 艾字节内存；这一数值约为 2022 年世界最大超级计算机可用内存的 500 倍。

不过，虽然多体量子体系的 Hilbert 空间具有指数大的维数，物理相关的状态通常局限在 Hilbert 空间中维数有限的一个角落。例如，许多物理 Hamiltonian 只含局域相互作用，这会显著约束相应多体波函数的形式。

变分方法背后的主要思想，是在所关注的 Hilbert 空间内寻找物理相关量子态的一种计算高效表示。

变分方法 (variational method) 通过把波函数的复振幅编码为一个依赖参数集合 θ 的参数化函数 (通常称为 Ansatz (ansatz))，规避指数复杂度问题。如果参数数目随体系大小多项式增长，就能用有限的计算资源高效存储状态。一般而言，变分态 (variational state) $|\Psi_\theta\rangle$ 可在计算基上展开为

$$|\Psi_\theta\rangle = \sum_{s=1}^{2^N} \Psi_\theta(s) |s\rangle, \quad (5.2)$$

其中 $\Psi_{\theta}(\mathbf{s}) = \langle \mathbf{s} | \Psi_{\theta} \rangle$ 表示与状态 $|\mathbf{s}\rangle$ 对应的概率振幅. 此后的任务, 是找出能最好描述目标量子态的参数化 θ , 例如给定 Hamiltonian 的基态.

5.1 变分方法

即使采用变分态, 计算期望值仍可能具有指数复杂度, 因为这类计算必须对 Hilbert 空间的全部基元素求和. 在实际可用的变分态中, 有两种可能的方法, 由此区分出两族变分 Ansatz: 一族能够以多项式成本精确计算期望值; 另一族只能近似计算期望值, 但其精度可以体系大小的多项式成本提高. 对前一族, 观测量期望值的唯一误差来源, 是截断 Hilbert 空间中 (指数大的) 区域所造成的波函数表示能力限制. 对后一族, 通常还存在一个来自采样的附加误差; 不过该误差不一定带来系统误差, 并且可以额外计算成本加以改善.

第三类由计算期望值的成本随体系大小指数增长参数化量子态构成. 在实际应用中, 例如对二维张量网络, 会引入计算期望值的近似算法. 然而严格来说, 它们不是变分方法, 因为我们无法在多项式时间内以任意精度计算期望值, 而且它们会引入超出纯变分误差的系统偏差.

5.1.1 具有精确期望值的变分态

在第一类变分态中, 我们主要遇到局域受限的 Ansatz; 平均场态和矩阵乘积态是其中的重要例子.

平均场态 (mean-field state) 是最简单的变分量子态之一. 在这种方法中, 我们用平均场近似来模拟变分波函数, 即把它写成单自旋波函数的张量积

$$\begin{aligned} |\Psi_{\theta}\rangle &= |\phi_1(\theta_{\uparrow}^{(1)}, \theta_{\downarrow}^{(1)})\rangle \otimes |\phi_2(\theta_{\uparrow}^{(2)}, \theta_{\downarrow}^{(2)})\rangle \otimes \cdots \otimes |\phi_N(\theta_{\uparrow}^{(N)}, \theta_{\downarrow}^{(N)})\rangle \\ &= \bigotimes_{i=1}^N |\phi_i(\theta_{\uparrow}^{(i)}, \theta_{\downarrow}^{(i)})\rangle. \end{aligned} \quad (5.3)$$

这里, $|\phi_i\rangle$ 是站点 i 处的单自旋波函数. 它们满足正交条件 $\langle \phi_i | \phi_j \rangle = \delta_{ij}$, 其中 δ_{ij} 表示 Kronecker delta. 这样一来, $|\phi_i\rangle$ 只有两个系数, 分别对应自旋向上或向下的概率振幅; 我们把它作为变分参数:

$$|\phi_i\rangle = \theta_{\uparrow}^{(i)} |\uparrow\rangle + \theta_{\downarrow}^{(i)} |\downarrow\rangle, \quad (5.4)$$

$$|\theta_{\uparrow}^{(i)}|^2 + |\theta_{\downarrow}^{(i)}|^2 = 1. \quad (5.5)$$

因此总共有 $2N$ 个复参数, 即 $\theta = \{\theta_{\uparrow}^{(i)}, \theta_{\downarrow}^{(i)} \mid i = 1, 2, \dots, N\}$.

利用这一族波函数, 可以精确计算量子 Hamiltonian 的期望值. 这是因为, 我们能够利用波函数的张量积结构, 把多体态上的期望值化简为相应单体态上的期望值. 例如, 作用在第 i 个站点上的 Pauli 算符 σ_i^x 的期望值可写为 $\langle \Psi_{\theta} | \sigma_i^x | \Psi_{\theta} \rangle = \langle \phi_i | \sigma_i^x | \phi_i \rangle$. 这一计算很直接, 因为 $|\phi_i\rangle$ 是二维向量, 而 σ_i^x 是 2×2 矩阵.

然而，平均场态无法捕捉局域自由度之间的关联。张量网络态 (tensor network state, TNS) 是一族克服这一局限的量子态，其中一部分也允许精确计算期望值。具有这一性质且应用最广泛的张量网络态之一，是矩阵乘积态 (matrix product state, MPS)；它在一维体系研究中占据主导地位。

考察式 5.1 中定义的系数 $C_{\sigma_1, \sigma_2, \dots, \sigma_N}$ 。可以把 $C_{\sigma_1, \sigma_2, \dots, \sigma_N}$ 看成具有 N 个指标的张量；它总能表示为张量 A^{σ_i} 的缩并：

$$C_{\sigma_1, \dots, \sigma_N} = \sum_{\alpha, \beta, \dots, \gamma} A_{\alpha, \beta}^{\sigma_1} A_{\beta, \delta}^{\sigma_2} \dots A_{\gamma, \alpha}^{\sigma_N}. \quad (5.6)$$

希腊指标 $\alpha, \beta, \dots$ 的最大维数称为键维数 (bond dimension) χ 。这样，精确表示 $C_{\sigma_1, \dots, \sigma_N}$ 需要指数多的参数；也就是说，键维数 χ 必须随 N 指数增长。矩阵乘积态 Ansatz 的思想，是截断张量 A^{σ_i} 的指标维数。截断后，Ansatz 的参数数目降为 $\mathcal{O}(dN\chi^2)$ ，其中 d 是局域 Hilbert 空间维数，例如对自旋-1/2 粒子有 $d = 2$ 。通常利用张量 A^{σ_i} 的奇异值分解，以优雅且可控的方式截断键维数；它与矩阵乘积态能够包含的最大纠缠熵严格相关，¹详见节 5.2.3。

最后提及 S. White 提出的一种重要算法，它用于最小化变分量子态的能量，称为密度矩阵重整化群 (density matrix renormalization group, DMRG) [249]。该算法特别适合矩阵乘积态；二者结合，是目前计算一维体系基态波函数的最先进技术。不过，对这一算法的介绍超出了本书范围。关于矩阵乘积态用法的完整综述，见文献 [250]；关于张量网络方法的综述，见文献 [251]。

5.1.2 具有近似期望值的变分态

计算可处理态 (computationally tractable state) 是我们遇到的第二族变分态 [252]。

变分 Ansatz 必须满足两个条件，才能在计算上可处理：

- 能够高效计算任意单个基元素的振幅 $\Psi_{\theta}(s) = \langle s | \Psi_{\theta} \rangle$ 。
- 能够从 Born 分布 $P(s) = \frac{|\langle s | \Psi_{\theta} \rangle|^2}{\langle \Psi_{\theta} | \Psi_{\theta} \rangle}$ 高效生成样本 s 。

若满足这两个条件，就能高效估计任意 k -局域算符的期望值；增加样本数，可以严格控制随机采样导致的统计误差。因此，计算期望值的时间同时关于体系大小与精度呈多项式标度。

k -局域算符 (k -local operator) 是所含各项至多同时作用于 k 个局域量子数的算符。例如，最近邻 Hamiltonian 是 2-局域 Hamiltonian，因为它包含作用于 2 个量子比特的项。

¹事实上，键维数就是量子态 Schmidt 分解的秩。

一般地，给定变分态 $|\Psi_\theta\rangle$ ，算符 $\hat{O}$ 的期望值可表示为

$$\langle \hat{O} \rangle = \frac{\langle \Psi_\theta | \hat{O} | \Psi_\theta \rangle}{\langle \Psi_\theta | \Psi_\theta \rangle} \quad (5.7)$$

$$= \frac{\sum_{s,s'} \langle \Psi_\theta | s \rangle \langle s | \hat{O} | s' \rangle \langle s' | \Psi_\theta \rangle}{\sum_s |\langle \Psi_\theta | s \rangle|^2} \quad (5.8)$$

$$= \frac{\sum_s \langle \Psi_\theta | s \rangle \frac{\langle s | \Psi_\theta \rangle}{\langle s | \Psi_\theta \rangle} \sum_{s'} \langle s | \hat{O} | s' \rangle \langle s' | \Psi_\theta \rangle}{\sum_s |\langle \Psi_\theta | s \rangle|^2} \quad (5.9)$$

$$= \frac{\sum_s |\langle \Psi_\theta | s \rangle|^2 \sum_{s'} \langle s | \hat{O} | s' \rangle \frac{\langle s' | \Psi_\theta \rangle}{\langle s | \Psi_\theta \rangle}}{\sum_s |\langle \Psi_\theta | s \rangle|^2}. \quad (5.10)$$

这里，我们在分子中插入了两个形如 $\sum_s |s\rangle \langle s| = \mathbb{1}$ 的恒等算符，并在分母中插入了一个；随后又在分子中乘以 $\frac{\langle s | \Psi_\theta \rangle}{\langle s | \Psi_\theta \rangle}$ ² 可以辨认出两个主要部分：

$$P(\mathbf{s}) = \frac{|\langle \Psi_\theta | \mathbf{s} \rangle|^2}{\sum_s |\langle \Psi_\theta | \mathbf{s} \rangle|^2}, \quad (5.11)$$

$$O_{\text{loc}}(\mathbf{s}) = \sum_{s'} \langle \mathbf{s} | \hat{O} | s' \rangle \frac{\langle s' | \Psi_\theta \rangle}{\langle \mathbf{s} | \Psi_\theta \rangle}. \quad (5.12)$$

其中， $O_{\text{loc}}(\mathbf{s})$ 称为 $\hat{O}$ 的局域估计量 (local estimator)。因而，观测量 $\hat{O}$ 的量子期望值可以写成其局域估计量 O_{loc} 在概率分布 $P(\mathbf{s})$ 上的统计期望：

$$\langle \hat{O} \rangle = \sum_{\mathbf{s}} P(\mathbf{s}) O_{\text{loc}}(\mathbf{s}) = \langle O_{\text{loc}}(\mathbf{s}) \rangle_P. \quad (5.13)$$

需要强调，这些计算只适用于具有下述性质的算符：对任意 $\mathbf{s}$ ，满足 $|\langle \mathbf{s} | \hat{O} | s' \rangle| \neq 0$ 的状态 s' 的数目，至多随自旋数多项式增长。容易看出， k -局域算符满足这一性质。反之，如果式 5.12 中对 s' 的求和包含指数多个元素，那么求值 $O_{\text{loc}}(\mathbf{s})$ 就不是计算可处理的。

上述步骤允许我们直接从 $P(\mathbf{s})$ 抽取一系列状态 $\mathbf{s}^{(1)}, \mathbf{s}^{(2)}, \dots, \mathbf{s}^{(M)}$ ，并用下列算术平均近似 $\langle \hat{O} \rangle$ ，从而获得期望值的可控随机估计：

$$\langle \hat{O} \rangle \approx \frac{1}{M} \sum_{i=1}^M O_{\text{loc}}(\mathbf{s}^{(i)}). \quad (5.14)$$

这一估计的统计误差为 $\varepsilon = \sqrt{\sigma^2/M}$ ；只要 O_{loc} 的方差 σ^2 有限，误差就是有界的。例如，当 $\hat{O}$ 是系数有界的 k -局域自旋算符时，其方差严格有限，因为可以证明 $\sigma^2 = \langle \hat{O}^2 \rangle - \langle \hat{O} \rangle^2$ ³。因此，期望值估计误差按 $\varepsilon \sim 1/\sqrt{M}$ 下降；由于 $\lim_{M \rightarrow \infty} \varepsilon = 0$ ，增加样本数 M 就能达到任意精度。

然而，如果变分 Ansatz $\Psi_\theta(\mathbf{s})$ 由一个可以高效计算但除此之外任意的函数参数化，那么从 Born 分布生成样本集合 $\{\mathbf{s}^{(i)}\} \sim P(\mathbf{s})$ 一般并非平凡的计算任务。从 $P(\mathbf{s})$

²注意，这一操作始终成立，因为满足 $\langle s | \Psi_\theta \rangle = 0$ 的振幅从不出现在对 s 的求和中。

³还容易证明，当 $|\psi_\theta\rangle$ 趋近 $\hat{O}$ 的本征态时，方差趋于零。因而取 $\hat{O} = \hat{H}$ 时，随着状态趋近基态（或任意激发态），统计误差也趋于零。

采样最常用的策略之一，是采用 Markov 链 Monte Carlo (Markov chain Monte Carlo, MCMC) 方法，包括 Metropolis–Hastings 方法；它们生成一系列服从正确分布的样本 $\mathbf{s}^{(i)}$ 。

Metropolis–Hastings 方法构造一个满足目标概率分布细致平衡 (detailed balance) 关系的 Markov 随机过程：

$$P(\mathbf{s})\mathcal{T}(\mathbf{s} \rightarrow \mathbf{s}') = P(\mathbf{s}')\mathcal{T}(\mathbf{s}' \rightarrow \mathbf{s}). \quad (5.15)$$

其中， $\mathcal{T}(\mathbf{s}^{(i)} \rightarrow \mathbf{s}^{(i+1)})$ 是第 i 步的状态 $\mathbf{s}^{(i)}$ 在下一步转移到状态 $\mathbf{s}^{(i+1)}$ 的概率。因为过程具有 Markov 性，每一步的转移概率只依赖当前构型。细致平衡条件保证，无论初始构型 $\mathbf{s}^{(0)}$ 如何，序列在长时间极限下最终都会收敛到正确分布 $P(\mathbf{s})$ 。

转移概率 $\mathcal{T}$ 的一种可能选择由 Metropolis–Hastings 算法 (Metropolis–Hastings algorithm) 给出 [253]。主要思想是用局域转移核 T 与接受概率 A 表示 $\mathcal{T}$ ：

$$\mathcal{T}(\mathbf{s} \rightarrow \mathbf{s}') = T(\mathbf{s} \rightarrow \mathbf{s}')A(\mathbf{s} \rightarrow \mathbf{s}'). \quad (5.16)$$

这样，我们把全局随机过程分解成两个可以高效计算的局域子过程之积。例如，很容易找到一个归一化局域转移核，使其只修改少数自由度，如翻转给定构型中的单个自旋。相反，很难找到一个作用于所有自旋的归一化全局核。

通过一次局域转移从构型 $\mathbf{s}$ 前往 $\mathbf{s}'$ 的接受概率定义为

$$A(\mathbf{s} \rightarrow \mathbf{s}') = \min \left(1, \frac{P(\mathbf{s}')T(\mathbf{s}' \rightarrow \mathbf{s})}{P(\mathbf{s})T(\mathbf{s} \rightarrow \mathbf{s}')} \right). \quad (5.17)$$

Born 概率的归一化因子会相消，从而得到

$$\frac{P(\mathbf{s}')}{P(\mathbf{s})} = \left| \frac{\langle \mathbf{s}' | \Psi_\theta \rangle}{\langle \mathbf{s} | \Psi_\theta \rangle} \right|^2. \quad (5.18)$$

因此，我们可以考虑未归一化的变分 Ansatz。此外，如果变分态在计算上可处理，那么只要转移概率仅作用于基元素，它也具有可处理的复杂度。

选择有效的转移规则 $T(\mathbf{s} \rightarrow \mathbf{s}')$ 并不容易；对于具有对称性的体系尤其需要谨慎。例如，若计算基方向上的总磁化强度已知，我们可能希望将其固定，并采用不会把 Markov 链投影到某一区域之外的转移规则。一般而言，一个计算昂贵但有效的转移核选择，是直接使用 Hamiltonian：

$$T(\mathbf{s} \rightarrow \mathbf{s}') = \frac{|\langle \mathbf{s} | \hat{H} | \mathbf{s}' \rangle|(1 - \delta_{\mathbf{s}, \mathbf{s}'})}{\sum_{\mathbf{s}' \neq \mathbf{s}} |\langle \mathbf{s} | \hat{H} | \mathbf{s}' \rangle|}. \quad (5.19)$$

这称为 Hamiltonian 转移规则 [246]。

由此，从随机构型 $\mathbf{s}^{(0)}$ 出发，利用 Metropolis–Hastings 算法，根据 $T(\mathbf{s} \rightarrow \mathbf{s}')$ 迭代提出局域修改 $\mathbf{s}'$ ，再依照 $A(\mathbf{s} \rightarrow \mathbf{s}')$ 接受这些修改，就能从 $P(\mathbf{s})$ 采样。

不过，这一采样过程并不完美。如果所采样的分布过于复杂，它可能无法在合理的迭代次数内收敛。此外，因为自旋是逐次翻转的，样本之间存在关联。更多细节见 [算法 6](#)。

算法 6 Metropolis–Hastings 算法

```
 $s \leftarrow \text{uniform} \in [1, 2^N]$  ▷ 均匀随机抽取初始状态  
for  $i = 1$  to  $M$  do  
    按  $T(s \rightarrow s')$  提出  $s'$   
     $A \leftarrow \frac{P(s')T(s' \rightarrow s)}{P(s)T(s \rightarrow s')}$  ▷ 计算接受概率  
     $\xi \leftarrow \text{uniform} \in [0, 1]$   
    if  $\xi \leq A$  then  
         $s \leftarrow s'$  ▷ 更新状态  
    end if  
end for
```

5.2 表示波函数

既然已经了解如何利用参数化量子态计算所关注的物理量，下面深入讨论如何在实践中构造富有表达能力的变分态。其主要思想是：需要用一种灵活且足够一般、能够描述物理体系，同时只涉及多项式数量参数的参数化来表示高维函数。

传统上，研究者依赖受物理启发的变分 Ansatz。Jastrow 波函数 (Jastrow wave function) [254, 255] 是其中最成功、应用最广泛的形式之一。它基于二体相互作用在物理上最为重要这一假设，并为每一对相互作用粒子赋予一个可训练势。形式上，

$$\Psi_{\theta}(\mathbf{s}) = e^{-\frac{1}{2} \sum_{i \neq j} \theta_{ij} \sigma_i \sigma_j}. \quad (5.20)$$

其中，求和遍历所有可能的自旋对， θ_{ij} 是编码成对自旋关联的参数。因而，对含 N 个自旋的体系，所得波函数具有 $\mathcal{O}(N^2)$ 个参数。此外，在平移不变体系中，可以让参数 θ_{ij} 只依赖 i 与 j 之间的距离，从而把参数数目降为 $\mathcal{O}(N)$ 。

人工神经网络已经取代更传统的 Ansatz，用来直接逼近波函数 [246]。这一族变分态称为神经网络量子态 (neural quantum state, NQS)。例如，可以把参数化波函数写成前馈神经网络。此时， $\Psi_{\theta}(\mathbf{s})$ 对应神经网络的输出，而网络以向量形式的构型 $\mathbf{s}$ 作为输入。

在深度为 D 的前馈神经网络中，每一层 l 都包含一个非线性激活函数 $g^{(l)}$ ；它逐分量作用于权重矩阵 $\mathbf{W}^{(l)}$ 乘以前一层输出所得的向量。因而，可以把变分态写成运算 $g^{(l)} \cdot \mathbf{W}^{(l)}$ 的复合，其中 “ $\cdot$ ” 表示逐点运算：

$$\Psi_{\theta}(\mathbf{s}) = g^{(D)} \cdot \mathbf{W}^{(D)} \dots g^{(2)} \cdot \mathbf{W}^{(2)} g^{(1)} \cdot \mathbf{W}^{(1)} \mathbf{s}. \quad (5.21)$$

因此，输出是表示构型 $\mathbf{s}$ 概率振幅的标量，可以是复数或实数。

从数学角度看，这些 Ansatz 很有意义，因为神经网络服从通用表示定理 [75]，见节 2.4.4。根据式 2.46，可以用多项式数量 $\mathcal{O}(N^2)$ 的一维非线性函数表示多体波函数，其中 N 表示自旋数。

然而，这些结果适用于式 2.46 中的任意非线性函数 $\zeta_i, \varsigma_{i,j}$ ；为了表示目标函数，必须恰当地找到这些函数。实践中，神经网络采用固定的非线性激活，而我们只能调整运算数目。在这种情况下，神经元数目没有严格的多项式标度；最坏情形下，它可能随 N




图 5.1: 表示 N 自旋体系波函数的受限 Boltzmann 机图示, 其中 $\mathbf{s} = (\sigma_1, \sigma_2, \dots, \sigma_N)$ 为可见单元, $\mathbf{h} = (h_1, h_2, \dots, h_d)$ 为隐藏单元.

指数增长 [76]. 尽管如此, 计算机视觉和自然语言处理中的最先进成果 [256, 257, 258] 足以激励我们采用类似技术表示量子态. 注意, 量子态的神经网络表示不保持 Hilbert 空间结构. 这意味着, 对于神经网络表示 $|\psi_1\rangle$ 和 $|\psi_2\rangle$, 一般不能仅把参数相加, 就构造出由相同大小神经网络表示的有效波函数 $|\psi\rangle = |\psi_1\rangle + |\psi_2\rangle$, 因为 Ansatz 通常是非线性的.

5.2.1 受限 Boltzmann 机

神经网络量子态最初利用受限 Boltzmann 机 (restricted Boltzmann machine, RBM) 引入 [246]. 受限 Boltzmann 机是包含两个全连接层的浅层模型: 一个由 N 个单元组成的可见层, 以及一个由 M 个单元组成的隐藏层. 图 5.1 给出其架构示意图. 受限 Boltzmann 机 Ansatz 的波函数振幅为

$$\Psi_{\theta}(\mathbf{s}) = \sum_{\mathbf{h}} e^{\mathbf{b}_v^{\dagger} \mathbf{s} + \mathbf{b}_h^{\dagger} \mathbf{h} + \mathbf{h}^{\dagger} \mathbf{W} \mathbf{s}}. \quad (5.22)$$

其中, $\mathbf{s}$ 、 $\mathbf{h}$ 分别表示可见单元和隐藏单元, 参数 $\theta = \{\mathbf{b}_v, \mathbf{b}_h, \mathbf{W}\}$ 分别表示可见偏置、隐藏偏置和权重矩阵. 从神经网络视角看, 受限 Boltzmann 机是单层非线性前馈神经网络, 其中可见单元充当输入, 指数函数充当激活函数. 隐藏层带有偏置很常见 (见节 2.4.4), 但受限 Boltzmann 机还具有与输入值相连的、略显不同寻常的偏置; 下一段将解释其原因.

受限 Boltzmann 机在构造上经过专门设计, 使得式 5.22 中对隐藏单元的求和能够解析完成. 为看出这一点, 取二元隐藏单元 $h_i \in \{-1, 1\}$, 可以把式 5.22 改写为如下可

处理形式：

$$\Psi_{\theta}(\mathbf{s}) = e^{b_v^{\dagger} \mathbf{s}} \prod_{i=1}^M 2 \cosh(\mathbf{b}_{h,i} + \mathbf{W}_i \cdot \mathbf{s}). \quad (5.23)$$

其中， $\mathbf{b}_{h,i}$ 和 $\mathbf{W}_i$ 分别表示第 i 个隐藏偏置与权重矩阵的第 i 行。处理自旋体系时，可见单元表示 N 个物理自旋，因此受限 Boltzmann 机的输入就是自旋构型 $\mathbf{s}$ 。这样就得到一个解析表达式，可以求出给定自旋构型的振幅，进而用这一 Ansatz 表示完整波函数。

还可以把隐藏单元解释为 M 个隐藏自旋；在这一图景下，可以把受限 Boltzmann 机看成相互作用强度为 $\mathbf{W}_{ij}$ 的相互作用自旋模型。此外，还可以把受限 Boltzmann 机视为一个具有相关能量的模型，该能量依赖其参数、输入和隐藏自旋值。这称为基于能量的模型 (energy-based model)，也解释了式 5.22 中为何存在输入偏置。事实上，受限 Boltzmann 机等价于 Hopfield 网络 (Hopfield network)，即一种自旋玻璃 [259]。关于这一视角的更多细节，见文献 [260]。

由于受限 Boltzmann 机最早在这一语境中引入，神经网络量子态的多数早期工作都采用它；但近年来，其他架构也得到系统探索。多项工作研究了受限 Boltzmann 机的容量及其与量子纠缠的关系 [261, 262]。为解决更复杂的问题，人们还引入了这一架构的扩展——深度受限 Boltzmann 机 [263]，它由两个以上全连接层堆叠而成。

5.2.2 自回归与循环神经网络

如节 2.4.6 所述，自回归神经网络 (ARNN) 也可用于构造神经网络量子态；这一方法由文献 [92] 引入，后来同时应用于量子问题 [264] 与经典问题 [88]。它们的主要优点是 Born 概率分布已归一化，因而可以直接进行（自回归）采样，并且比 Markov 链 Monte Carlo (MCMC) 更容易并行化。图 5.2 给出了网络与采样算法的图示。

与式 2.47 类似，我们把多体波函数表示为条件复振幅的乘积：

$$\Psi_{\theta}(\mathbf{s}) = \prod_{i=1}^N \phi_i(\sigma_i | \sigma_{i-1}, \dots, \sigma_1). \quad (5.24)$$

它满足归一化条件 $\sum_{\sigma} |\phi_i(\sigma | \sigma_{i-1}, \dots, \sigma_1)|^2 = 1$ 。采用这一架构，我们可以通过直接采样状态构型来计算期望值，而不必例如借助 Metropolis-Hastings 算法构造 Markov 链（见算法 6）。采样状态构型时，我们逐个自旋迭代采样：首先从约化概率分布 $|\phi(\sigma_1)|^2$ 中采样第一个自旋 σ_1 ；然后依照条件概率分布 $|\phi_2(\sigma_2 | \sigma_1)|^2$ 采样第二个自旋 σ_2 ，再依照 $|\phi_3(\sigma_3 | \sigma_2, \sigma_1)|^2$ 采样下一个，如此继续直至 σ_N 。这种采样过程天然易于并行。⁴

这种采样过程产生独立同分布样本。相反，MCMC 方法可能会产生高度相关的连续样本，对远非 Gaussian 分布等复杂概率分布而言，这会带来问题。⁵ 考虑一个概率集

⁴我们可利用中间条件概率以较低计算成本抽取样本；例如，使用 $N-1$ 个自旋的概率，再对最后一个自旋采样，就可得到新样本；MCMC 无法这样做。

⁵Markov 链 Monte Carlo (MCMC) 方法（如 Metropolis-Hastings 算法）一般依靠修改自旋构型来采样后续状态。因此，这一过程可能产生高度相关的连续样本，并对结果造成负面影响。为了计算期望值，我们需要估计自相关时间，以便从所得链中抽取不相关样本。此外，在接近相变点时，这类方法会遭遇临界慢化，使不相关构型的采样在许多情况下无法实现。




图 5.2: 用于四自旋的 ARNN 量子态示例. (a) 网络的图示. 为了不破坏输出概率分布的条件结构, 表示模型权重的箭头是倾斜的. 由于删除了部分连接, 这些层是“掩蔽的”. (b) 采样算法. 每一步都在条件概率上直接采样, 由此依次采样各个自旋. 改编自文献 [92].

中在 Hilbert 空间内若干分离区域的量子态. 在这种情况下, Markov 链通常会困在其中一个区域, 因为从一个区域移动到另一个区域必须经历若干个受惩罚的步骤, 从而导致高度不准确的采样. 相比之下, 直接采样过程能按照概率分布, 顺畅地抽取属于所有这些区域的自旋构型, 从而得到好得多的样本.

量子物理中最早的自回归模型由掩蔽的稠密层或卷积层构成, 模仿所谓的 PixelNet 架构 [265]; 之后, 人们又引入了循环神经网络 [266]. 受自然语言处理模型启发的循环神经网络 (RNN) 也是生成模型. 我们可以在句子中各元素处在庞大“词空间”时的关联, 与自旋构型之间作一个简单类比. 对自旋体系, 如果假定存在某种隐结构, 那么量子态存在关联, 而它们的基元素就是 Hilbert 空间的元素. 遵循这一类比, Hibat-Allah 等人引入了 RNN 波函数 [266], 即使对挫折体系也取得了令人印象深刻的结果. 图 5.3 给出了这类架构的一个示例. 显然, 许多不同的神经网络架构都可行. 近年来, 大量不同架构都已实现为神经网络量子态, 例如卷积神经网络 [267] 和群卷积神经网络 [268]; 后者可以方便地实现某些对称性, 详见节 5.2.4.

5.2.3 容量与纠缠

正如我们在节 5.1 和节 5.2 中所述, 表示量子多体波函数的方法多种多样. 例如, 即使只考虑神经网络量子态, 基于不同神经网络架构的 Ansatz 之间也已经存在显著差异. 因而, 一个自然的问题是: 它们的表达能力如何, 彼此之间又应怎样比较?

张量网络已反复用于开展这类研究, 因为它们已经得到充分建立和刻画, 并且构成研究量子多体现象的一种理论语言. 出于这一原因, 学界投入了大量努力来研究张量网络态与神经网络量子态之间的关系 [269, 262, 270], 从而为神经网络量子态的表达能力提供认识 [271]. 在首次引入以受限 Boltzmann 机实现的神经网络量子态 [246] 之后, 早期工作着重寻找各种基于受限 Boltzmann 机的量子态与张量网络态之间的直接关系 [269, 262]. 已经证明, 神经网络能以对数空间复杂度、任意精度地高效逼近所有可




图 5.3: 用于神经网络量子态的 RNN 架构图示. 面板 (a) 对应实值波函数, 它可适用于某一类问题; 面板 (b) 对应复值波函数. 在两种方案中, 局域自旋构型 s_i 和隐向量 h_i 被输入一个执行非线性变换的 RNN 单元. 然后施加激活函数 (softmax 对应 ς , 和/或 softsign 对应 $\varsigma\varsigma$), 以得到与构型对应的最终概率和/或相位. 最后, 把概率 (和相位) 组合起来, 得到最终波函数振幅 $\psi(\mathbf{s})$.

高效缩并的张量网络. 因此, 对每个张量网络态, 都存在一个与之等价且规模为多项式量级的神经网络量子态. 反过来, 有些量子态可以用神经网络量子态高效描述, 但若用张量网络态表示, 则需要指数数量的参数. 因而, 张量网络态是神经网络量子态的一个子集 [270], 如图 5.4 所示.

衡量表达能力时, 我们往往依据不同 Ansatz 能够捕捉的纠缠. 例如, 平均场 Ansatz 在构造上就是乘积态 (回顾式 5.3). 因而, 它无法捕捉纠缠, 而张量网络态和神经网络量子态没有这种强烈的局域限制. 由此, 张量网络态与神经网络量子态具有比平均场态更高的表达能力.

更精确地说, 我们研究不同 Ansatz 所能捕捉的纠缠标度. 对密度矩阵为 ρ 的一般量子多体体系, 纠缠熵 (entanglement entropy) 定义为

$$S(\rho) = -\text{Tr} [\rho \log_2 \rho]. \quad (5.25)$$

它对任意纯态都为零. 考虑把体系划分成两个子集: I 及其补集 O , 并考虑约化密度矩阵 $\rho_I = \text{Tr}_O[\rho]$. 一般而言, ρ_I 表示一个混合态, 它可以具有非零的 von Neumann 纠缠熵. 对一般量子态, ρ_I 的纠缠熵随分割区域的体积增长. 因而, 它对应体积律标度 (volume-law scaling). 从受限 Boltzmann 机等非常基本的浅层架构 [261], 到卷积神经网络或循环神经网络等更现代、更深的方案 [271], 神经网络量子态都能高效捕捉这种标度. 一些传统 Ansatz, 例如 Jastrow 波函数 (见式 5.20), 也能捕捉体积律纠缠.⁶

然而, 有一类量子态的纠缠熵至多随两个区域之间的边界面积增长. 这称为面积律标度 (area-law scaling), 并且是局域有隙 Hamiltonian 基态的一种性质 [272]. 由于具有局域性质, 张量网络态能高效捕捉面积律纠缠 [273]. 例如, 在一维链中, 两个子系统之间分割面的面积是常数, 这意味着纠缠熵是常数, 而不是无限体积极限下的广延

⁶事实上, Jastrow Ansatz 是具有 $N(N-1)/2$ 个隐藏神经元的受限 Boltzmann 机波函数的一个特例 [269].




图 5.4: 不同类别变分态的表达能力; 文献 [270] 通过把张量网络态映射到神经网络量子态显式证明了这一关系. PEPS* 表示投影纠缠对态 (projected entangled pair state) 的一个子类; 投影纠缠对态是矩阵乘积态的推广. 改编自文献 [270].

量. 对键维数为 χ 的矩阵乘积态, 体系任意二分的 von Neumann 纠缠熵都具有上界 $S \leq \mathcal{O}(\log_2 \chi)$, 这使矩阵乘积态 Ansatz 成为研究一维体系的极佳候选.

只需观察这些 Ansatz 的构造方式, 我们就能在直观层面理解它们之间的大部分差异. 图 5.5 以图示给出了若干 Ansatz 在二维体系中可以建立的不同连接. 显然, 图 5.5(b) 所示的矩阵乘积态 Ansatz 受到的局域限制最强, 因为它只能沿蛇形路径考虑最近邻连接. 这实际上限制了矩阵乘积态能够捕捉的纠缠. 图 5.5(d) 所示的循环神经网络 Ansatz 虽然也只能沿与矩阵乘积态相同的路径解析状态, 却可以自由地计入额外信息, 因而能够捕捉更丰富的关联.

相反, Jastrow 波函数和受限 Boltzmann 机波函数等其他 Ansatz 分别如图 5.5(a) 和 (c) 所示, 可以在任意站点之间建立连接. 无论距离如何, Jastrow Ansatz 都能计入体系中所有可能的站点对. 受限 Boltzmann 机 Ansatz 则借助大小可变的辅助隐藏层推广了 Jastrow Ansatz. 通过隐藏神经元, 该 Ansatz 不再局限于成对连接, 实际上最多可以考虑全对全连接. 这种非局域特征使它们能够捕捉体积律纠缠.




图 5.5: 受文献 [269, 274] 启发的各种 Ansatz 示意图. (a) Jastrow Ansatz 在所有可能的站点对之间建立连接. (b) 矩阵乘积态 Ansatz 沿一条线连接最近邻站点. (c) 受限 Boltzmann 机 Ansatz 把所有站点连接到每个隐藏神经元, 不同隐藏神经元用不同颜色表示. (d) 循环神经网络 Ansatz 沿绿色箭头依次处理状态. 深蓝色箭头表示模型内部的信息流. 没有起始站点的箭头对应自由参数.

5.2.4 实现对称性

在神经网络量子态中编码对称性, 可以减少神经网络的参数数目, 把 Ansatz 所能覆盖的 Hilbert 空间区域限制到所关注的子空间, 从而提高结果的精度. 首先说明这里所说的对称性是什么. 考虑一组线性变换: 如果 Hamiltonian 在这些变换下不变, 即所有这些变换都与 Hamiltonian 对易, 那么该 Hamiltonian 在这个群下具有对称性. 晶格模型中一些最常见的对称性包括平移对称性、二维或更高维中的旋转对称性、反演或反射对称性, 以及这些变换的所有复合.

可以证明, 如果 Hamiltonian 与一组算符 $\mathcal{T} = \{\hat{T}_k\}_{k=1}^K$ 对易, 那么其基态也必定在这些变换下保持不变. 因而, 对于任意 $\hat{T}_k$, 两个构型 $|s\rangle$ 和 $|s(k)\rangle = \hat{T}_k |s\rangle$ 的振幅必须保持不变: $\Psi_\theta(s) = \Psi_\theta(\hat{T}_k s) \forall k$.⁷ 在神经网络量子态中引入对称性的一种方法, 是把 Ansatz 在对称不变构型集合 $\{s(k)\}$ 上求值所得的和作为输出. 这样一来, 输出在构造上就是不变的. 然而, 这种方法并未改善模型的性能.

一种更高效的方法, 是在神经网络量子态模型的开头构造一个满足对称性条件的稠密层 [267]. 我们可以用这项技术编码任何与规模为多项式量级的置换群同构的对称群.

⁷严格来说, 右端可以相差一个相位; 为方便起见, 我们忽略它.

这通常涵盖所有晶格对称性 (lattice symmetry) (平移、旋转、反射等), 以及全局自旋翻转等全局离散对称性, 但无法处理 $SU(2)$ 等连续对称性. 例如, 可以通过卷积来实现平移对称性, 其中卷积核的宽度与体系本身相同. 由于卷积按定义具有平移不变性, 不难看出该层的输出也是对称不变的.

对于受限 Boltzmann 机, 可以重新排列式 5.22 中的各项, 使其在一个对称群的群元作用下保持不变. 把局域自旋的变换记为 $\sigma_j(k) = \hat{T}_k \sigma_j$. 对称不变振幅可写为

$$\Psi_{\theta}(\mathbf{s}) = \sum_{\mathbf{h}} \exp \left(\sum_{f=1}^{\alpha} b_v^f \sum_{k=1}^K \sum_{j=1}^N s_j(k) + \sum_{f=1}^{\alpha} b_h^f \sum_{k=1}^K h_{f,k} + \sum_{f=1}^{\alpha} \sum_{k=1}^K h_{f,k} \sum_{j=1}^N W_j^f s_j(k) \right). \quad (5.26)$$

这里, 我们把矩阵乘积显式写成了求和. 关键在于, $\mathbf{b}_v^f, \mathbf{b}_h^f$ 现在是特征空间中的向量, 其中 $f = 1, \dots, \alpha$; 矩阵 $\mathbf{W}^f$ 的大小现在为 $\alpha \times N$.⁸ 如果考虑平移不变性, 相应的对称群由 N 个平移算符组成. 在这种情况下, 可以把 $\mathbf{W}^f$ 看成一个核, 它作用于已经施加平移算符的构型.

事实上, 直接在神经网络量子态中编码对称性的方法有很多. 关于一般前馈网络的更多细节, 见文献 [275]; 关于卷积神经网络的一个例子, 见文献 [267].

5.2.5 局限性

与许多机器学习方法类似, 神经网络量子态也存在可解释性问题; 对于一般机器学习方法, 我们已在节 3.5 中对此作了广泛讨论. 不过, 自 Carleo 和 Troyer 的开创性论文 [246] 以来, 这方面已经取得了显著进展. 例如, 近期一项工作引入了可解释的受限 Boltzmann 机 Ansatz: 作者在式 5.22 给出的概率分布表达式中加入若干关联项. 由此, 可以考察训练后参数的大小, 以理解哪些关联对给定物理问题更为重要 [276].

进一步理解神经网络量子态的另一条途径, 是把神经网络量子态架构映射到张量网络态等其他已知 Ansatz. 利用这一思路, 已有工作表明, 与张量网络态不同, 神经网络量子态能够描述体积律态, 见节 5.2.3. 就表达能力而言, 神经网络量子态可以高效表示一维有隙 Hamiltonian 的基态、所有能在经典计算机上高效缩并的张量网络态, 以及体积律态 [270]. 此外, 研究者还找到了若干有趣物质相的精确神经网络量子态表示, 例如拓扑态和稳定码 [261, 263, 269, 277, 278, 279, 280, 281]. 然而, 并非所有量子态都能用神经网络量子态高效表示. 例如, 我们无法表示随机态, 因为它们没有结构.

另一个重要方面, 是为问题选择合适的神经网络架构和训练策略. 例如, 我们可能希望实现某些对称性, 正如节 5.2.4 所讨论的那样. 然而, 对于给定问题, 某种神经网络量子态 Ansatz 可能非常适合该任务, 但训练过程却可能在数值上失败. 一些工作分析了涉及随机重构 (stochastic reconfiguration) 的训练过程 [282]. 另一些工作发现, 非可积体系动力学中涉及的状态无法由多种架构表示, 但其纠缠结构可以恢复; 这暗示着一种不同于基于张量网络的 Ansatz 内禀纠缠限制的局限 [283].

⁸注意, 这一表达式等价于具有 $M = K \times \alpha$ 个隐藏变量的式 5.22.

这些发现连同当前最先进的结果表明，神经网络量子态的表达能力优于现有模拟方法；不过，与本书讨论的许多机器学习方法一样，要充分理解其能力，仍有许多研究方向需要探索。

5.3 应用

本节介绍神经网络量子态的多种应用，从基态搜索到量子态层析，并涵盖实时动力学、量子电路和费米子体系。除了说明如何把前述方法应用于这些问题，我们还会给出每种应用的结果，并将其与其他最先进方法比较。由此，我们希望展示神经网络量子态方法的潜力与广泛适用性；这一领域仍然十分年轻。

5.3.1 寻找基态

与许多机器学习任务中的常见做法一样，我们定义一个依赖神经网络可训练参数的损失函数 $\mathcal{L}$ 。在这里，它对应变分能，即 Hamiltonian 在变分态中的期望值：

$$\mathcal{L}(\boldsymbol{\theta}) = E(\boldsymbol{\theta}) = \langle \Psi_{\boldsymbol{\theta}} | \hat{H} | \Psi_{\boldsymbol{\theta}} \rangle. \quad (5.27)$$

这一损失函数的选择很自然，因为它来自量子力学中的变分原理。

变分原理 (variational principle) 指出：给定 Hamiltonian $\hat{H}$ ，变分波函数 $|\Psi_{\boldsymbol{\theta}}\rangle$ 的能量 $E(\boldsymbol{\theta})$ 大于或等于精确基态能量，即

$$E(\boldsymbol{\theta}) = \frac{\langle \Psi_{\boldsymbol{\theta}} | \hat{H} | \Psi_{\boldsymbol{\theta}} \rangle}{\langle \Psi_{\boldsymbol{\theta}} | \Psi_{\boldsymbol{\theta}} \rangle} \geq E_0. \quad (5.28)$$

因此，能量是一个有效的损失函数：能量期望值越低，近似就越好。⁹

事实上，以物理原理为坚实基础的损失函数至关重要，因为它也使我们能够比较不同方法。例如，通过考察变分能，可以了解一种方法在求解给定问题时的表现：如果所得近似基态能量显著低于其他技术给出的结果，就可以相当有把握地认为，所找到的解质量更高。根据前文对算符期望值的一般讨论，变分能可以随机近似为

$$E(\boldsymbol{\theta}) \approx \frac{1}{M} \sum_i^M E_{\text{loc}}(\mathbf{s}^{(i)}). \quad (5.29)$$

其中， E_{loc} 是局域估计量，定义为 $E_{\text{loc}}(\mathbf{s}) = \sum_{s'} \langle s' | \hat{H} | s \rangle \frac{\langle s' | \Psi \rangle}{\langle s | \Psi \rangle}$ 。我们的目标是借助基于梯度的优化算法最小化这一损失函数。能量梯度也可用期望值写成¹⁰

$$\frac{\partial E(\boldsymbol{\theta})}{\partial \theta_p} = 2\Re [\langle E_{\text{loc}}(\mathbf{s}) O_p^*(\mathbf{s}) \rangle - \langle E_{\text{loc}}(\mathbf{s}) \rangle \langle O_p^*(\mathbf{s}) \rangle] \quad (5.30)$$

$$= 2\Re [\langle (E_{\text{loc}}(\mathbf{s}) - \langle E_{\text{loc}}(\mathbf{s}) \rangle) O_p^*(\mathbf{s}) \rangle]. \quad (5.31)$$

⁹需要强调，只有在精确计算期望值时，这一原理才有效。当能量作为随机平均计算时，其估计平均值可能低于精确能量。不过，如前所述，增加样本数并采用高效采样方法，会系统地减小落到精确能量以下的涨落。

¹⁰从计算角度说，不需要在内存中存储完整的 Jacobian 矩阵 $O_p(\mathbf{s})$ ；可以直接通过向量 $v = E_{\text{loc}}(\mathbf{s}) - \langle E_{\text{loc}}(\mathbf{s}) \rangle$ 与 Jacobian $O_p(\mathbf{s})$ 的向量-Jacobian 乘积 (vector-Jacobian product) (反向模式微分) 计算这一梯度。这种方法显著降低了内存与计算成本。更多细节见节 7.1。

这里假定参数为实数¹¹，且 θ_p 是神经网络量子态的第 p 个参数. 对角算符 $\hat{O}_p$ 定义为

$$O_p(\mathbf{s}) = \frac{\partial}{\partial \theta_p} \log \langle \mathbf{s} | \Psi_{\boldsymbol{\theta}} \rangle = \langle \mathbf{s} | \hat{O}_p | \mathbf{s} \rangle. \quad (5.32)$$

还应指出，式 5.31 采用的表达式具有协方差的形式，因而对采样噪声格外稳定. 尤其当波函数接近精确基态时，局域能量的统计涨落受到抑制；由于协方差结构，梯度的统计涨落也随之减小.

因此，学习算法很直接. 首先初始化权重 $\boldsymbol{\theta}^{(0)}$. 随后在每一步，按照 Born 分布采样由 M 个构型组成的序列： $P(\mathbf{s}; \boldsymbol{\theta}^{(s)}) \sim \mathbf{s}^{(1)} \dots \mathbf{s}^{(M)}$. 如上所述，这可以通过 Markov 链或直接采样技术完成.

下一步是计算局域能量的平均值 $E(\boldsymbol{\theta})$ ，由此得到 Hamiltonian 期望值的估计. 此外，也可按照式 5.31 计算梯度. 最后，可以选择任意一种基于梯度的优化器，更新下一步的参数. 例如，对普通梯度下降，有 $\theta_p^{(s+1)} = \theta_p^{(s)} - \eta \frac{\partial E(\boldsymbol{\theta})}{\partial \theta_p}$ ，其中 η 是学习率.

重复这一过程，直至它收敛到能量景观的一个极小值. 这里不存在训练数据集，因为该方法不基于任何监督学习方法. 实际上，这里的任务是：从相关 Born 分布抽取样本，并用神经网络对状态本身建模，从而确定最优的未知波函数. 算法 7 概括了这些步骤. 注意，这并不是最常用的算法，因为它的精度低于节 5.3.3 介绍的虚时演化.

算法 7 用神经网络量子态搜索基态

随机初始化 $\boldsymbol{\theta}$

for $i = 1$ **到** n_{steps} **do**

 按某种算法生成 M 个样本（通常使用 Markov 链）

 计算能量梯度 $\partial E(\boldsymbol{\theta}) / \partial \theta_p$

 按 $\theta_j \leftarrow \theta_j - \eta \partial E(\boldsymbol{\theta}) / \partial \theta_j$ 更新参数（或采用更高级的更新规则）

end for

返回 优化后的参数 $\boldsymbol{\theta}$

5.3.2 实时演化

神经网络量子态也可用于以变分方式执行实时演化 [285]，所采用的过程称为含时变分 Monte Carlo (time-dependent variational Monte Carlo, t-VMC) [286, 246, 267, 287]. 这对封闭的相互作用量子体系之非平衡量子动力学尤其重要. 研究这些问题，有助于理解复杂量子多体体系的临界性质、纠缠谱以及许多其他所关注的物理量. 要解决的问题是：利用参数化波函数 $|\Psi_{\boldsymbol{\theta}}(t)\rangle$ ，对含时 Schrödinger 方程（下文取 $\hbar = 1$ ）作时间积分：

$$i \frac{d |\Psi_{\boldsymbol{\theta}}(t)\rangle}{dt} = \hat{H} |\Psi_{\boldsymbol{\theta}}(t)\rangle. \quad (5.33)$$

¹¹实际上，并不一定要求参数为实数. 对复参数，表达式非常相似，不过必须谨慎处理非全纯 Ansatz. 注意，许多常见 Ansatz，尤其是大多数自回归 Ansatz，都不是全纯的. 相关讨论见文献 [284] 的附录.

也就是说，要对所有 t 找到 $|\Psi_\theta(t)\rangle$ 的正确形式. 把式 5.33 对 δ 展开到一阶，并与 $\langle s|$ 作内积，得到

$$\Psi_\theta(t + \delta)(s) = 1 - i\delta \langle s | \hat{H} | \Psi_\theta(t) \rangle + \mathcal{O}(\delta^2) \quad (5.34)$$

$$= 1 - i\delta E_{\text{loc}}(s) + \mathcal{O}(\delta^2). \quad (5.35)$$

这里使用了上一节式 5.29 定义的 $E_{\text{loc}}(s)$. 为了在下一时间步 $t + \delta$ 得到良好的状态变分近似，自然可定义代价函数 $\mathcal{L}(\tilde{\theta})$:

$$\mathcal{L}(\tilde{\theta}) = \text{dist}(|\Psi_{\tilde{\theta}}\rangle, |\Psi_\theta(t + \delta)\rangle). \quad (5.36)$$

其中， θ 是上一时间步的变分参数， $\tilde{\theta}$ 是待确定的变分参数. 如果时间步足够小，损失函数可以解析地最小化. 首先注意到 $\tilde{\theta} = \theta + \delta \dot{\theta} + \mathcal{O}(\delta^2)$. 因而，可以把变分态 $|\Psi_{\tilde{\theta}}\rangle$ 展开到一阶，再像处理式 5.34 那样与 $\langle s|$ 作内积：

$$\Psi_{\theta + \tau \dot{\theta}}(s) = \left(1 - \delta \dot{\theta} \partial_\theta \Psi_\theta(s)\right) \Psi_\theta(s) + \mathcal{O}(\delta^2). \quad (5.37)$$

我们需要考虑两个状态 $|\Psi\rangle$ 与 $|\phi\rangle$ 之间一种可以高效采样的距离度量. 这一选择有一定自由度，并可能导出略有不同的变分原理；关于这些问题的详细讨论，见文献 [285]. 考虑到许多神经网络量子态架构中的量子态未归一化，若采用非保真度 (infidelity)，则有¹²

$$\text{dist}(|\Psi\rangle, |\phi\rangle) = 1 - \frac{\langle \phi | \Psi \rangle \langle \Psi | \phi \rangle}{\langle \phi | \phi \rangle \langle \Psi | \Psi \rangle}. \quad (5.38)$$

把式 5.37 与式 5.34 代入式 5.38 的距离表达式，将其最小化并保留 δ 的领头项，就得到一个给出变分参数时间导数 $\dot{\theta}$ 的方程，从而可以采用 Runge–Kutta 积分等高阶积分方法：

$$S \dot{\theta} = -i f. \quad (5.39)$$

其中， S 是量子几何张量 (quantum geometric tensor)， f 是向量；它们的元素为

$$S_{pp'} = \langle O_p^* O_{p'} \rangle - \langle O_p^* \rangle \langle O_{p'} \rangle, \quad (5.40)$$

$$f_p = \langle E_{\text{loc}} O_p^* \rangle - \langle E_{\text{loc}} \rangle \langle O_p^* \rangle. \quad (5.41)$$

这里， O_p 由式 5.32 给出， E_{loc} 是局域能量. 向量 f 是局域能量对变分参数的梯度；类比经典力学，它常称为“力”向量. 几何张量的谱则编码变分空间的（线性化）曲率，类似于节 4.5 讨论的 Hessian. 关于含时变分原理的完整推导与深入讨论，见文献 [285].

对于用受限 Boltzmann 机优化基态的情形， S 的谱已得到广泛研究 [282]，并与所考察物理体系的不同区域联系起来. 实际上，求解线性系统式 5.39 意味着采用迭代求解器（例如共轭梯度法）或直接求解器（例如 QR 分解）. 一个重要的实际数值问题是，矩阵 S 往往是奇异的. 已有一些技术可对 S 作正则化，得到更稳定的动力学 [267, 288]. 无论如何，由于 S 与 f 都只能通过随机平均获得，稳定而准确的长时间动力学对神经网络量子态而言仍是一项挑战 [288].

¹²严格来说，应考虑 Fubini–Study 度量；不过，采用这里的距离会得到相同的方程.




图 5.6: 采用受限 Boltzmann 机得到的临界淬火动力学: 先把体系制备在 $h_i/J = 1/2$ 时 $\hat{H}_{\text{TFI}}$ 的基态, 再突然淬火到 $h_f/J = 1$. 这会激发体系临界点处的许多本征态; 这些态具有长程关联, 使动力学难以捕捉. 左图: 受限 Boltzmann 机取不同隐藏神经元密度 α 时, 沿 x 方向的平均磁化强度. 右图: 积分误差; 增大 α 会使其系统地减小. 取自文献 [246].

作为示例, 图 5.6 展示了一维自旋链的淬火动力学, 该自旋链服从带横场的 Ising Hamiltonian:

$$\hat{H}_{\text{TFI}} = -J \sum_j \hat{\sigma}_j^z \hat{\sigma}_{j+1}^z + h \sum_j \hat{\sigma}_j^x. \quad (5.42)$$

其中, J 是最近邻耦合, h 是横场强度. 该模型在一维 $h = J$ 处发生二阶相变, 把铁磁相 ($J > 0$) 或反铁磁相 ($J < 0$) 与顺磁相分隔开; 当 $h \gg J$ 时, 所有自旋都沿横场方向排列. 可以先把体系制备在某个 $h = h_i$ 对应的 Hamiltonian 本征态中, 再把 Hamiltonian 参数突然切换到 $h_f/J = 1$, 以研究临界淬火动力学. 如图 5.6 所示, 受限 Boltzmann 机能捕捉直至约 $Jt = 1.5$ 的动力学; 增加隐藏层数 α 会系统地提高精度. 如前所述, 较新的工作还在二维体系上使用卷积神经网络得到了结果; 这类体系的动力学对张量网络方法颇具挑战 [267].

5.3.3 虚时演化

节 5.3.1 中用于估计多体体系基态的一阶优化方案, 可以改进得更为精确. 为此, 考虑通过 Wick 旋转 (Wick rotation) $t \rightarrow i\tau$ 实现的虚时演化 (imaginary-time evolution) 很有用:

$$|\psi_\theta(\tau)\rangle = \exp(-\tau \hat{H}) |\psi_\theta(0)\rangle. \quad (5.43)$$

其中, $\hat{H}$ 是 Hamiltonian, τ 是实数. 可以证明, $\lim_{\tau \rightarrow \infty} |\psi_\theta(\tau)\rangle = |\phi_0\rangle$, 其中 $|\phi_0\rangle$ 是 Hamiltonian 的精确基态, 条件是 $|\langle \psi_\theta(\tau) | \phi_0 \rangle| \neq 0$. 此外, 可以证明虚时演化以 τ 的指数速度收敛到精确基态, 因而提供了一种系统寻找基态的方法. 与实时演化类似, 虚时演化也可以用变分方式执行. 这会得到与式 5.39 同类型的方程:

$$S\dot{\theta} = -f. \quad (5.44)$$

由于式 5.43 中的指数形式，这里少了因子 i 。因而，所得过程与实时演化非常相似，可以按照上式给出的更新来更新权重。

算法 8 概括了实时和虚时两种变分时间演化。对虚时演化，通常还会修改算法，与单位矩阵成正比的常数 $\Lambda > 0$ 正则化矩阵 $\mathbf{S}$: $\mathbf{S} \rightarrow \mathbf{S} + \Lambda \mathbf{I}$ 。此时就恢复了 S. Sorella 最初引入的随机重构方法 [289, 290]。

算法 8 神经网络量子态的实时 ($\xi = i$) 或虚时 ($\xi = 1$) 演化算法

随机初始化 θ

for $i = 1$ **到** n_{steps} **do**

 计算 $S_{pp'}$ 和 F_p

 通过求解方程 $\sum_{p'} S_{pp'} \dot{\theta}_{p'} = -\xi F_p$ 得到 $\dot{\theta}$ (并可作正则化)

 使用常微分方程 (ordinary differential equation, ODE) 积分器更新 θ

end for




图 5.7: 虚时演化搜索基态所得结果相对于精确解的相对误差。左图：横场 Ising 模型基态的相对误差；对于不同 h/J ，将误差画成 $\alpha = M/N$ 的函数，其中 M 是隐藏单元数， $N = 80$ 是自旋数。中图：反铁磁 Heisenberg 模型基态的相同图线，并与另一种变分 Ansatz——Jastrow 波函数比较。右图：与最先进张量网络结果的比较，表明神经网络量子态的表现至少同样好。取自文献 [246]。

图 5.7 展示了在横场 Ising 模型和 Heisenberg 模型上执行虚时演化的结果 [246]。这些结果说明两个重要特征：其一，采用受限 Boltzmann 机 Ansatz 时，增大 $\alpha = M/N$ (M 为隐藏单元数) 可以系统地减小相对误差；其二，所得精度高于最先进的张量网络方法。

5.3.4 费米子体系

费米子 (fermion) 是两类基本亚原子粒子之一。因此，费米子体系广泛存在于量子多体物理、高能物理和化学中。然而，费米子体系的经典模拟很困难，因为费米子算符服从反对易关系 (anticommutation relation)；这要求费米子体系的波函数在交换粒子时具有反对称性 (antisymmetry)。由于著名的符号问题 (sign problem) [291]，所有已知的量子 Monte Carlo 方法在计算费米子体系时都会变得极其昂贵。

费米子神经网络量子态的变分方法可分为两类。第一类采用一次量子化 (first quantization)，把波函数构造成为 Slater 行列式 (Slater determinant)，从而施加反对称性。第

二类采用二次量子化 (second quantization), 把费米子多体 Hamiltonian 映射为自旋 Hamiltonian. 第一种方法基于连续状态空间中的问题表述, 已经在现实体系上取得许多令人瞩目的结果 [292, 293, 294]. 关于这一主题, 可进一步阅读近期综述 [295]. 下文将集中讨论基于二次量子化的第二种方法.

如前所述, 模拟费米子体系的一种便利方法, 是把费米自由度映射为自旋. 一种通用方案是 Jordan–Wigner 变换 (Jordan–Wigner transformation), 它能把费米子问题映射为相互作用自旋问题. 还有许多其他变换, 主要是在量子模拟语境中发展起来的, 例如 Bravyi–Kitaev 编码 (Bravyi–Kitaev encoding) [296]. 历史上, Jordan–Wigner 技术曾用于求解自旋模型 [297]. 这里则反其道而行: 把费米子算符映射为自旋算符, 以便使用神经网络量子态和本章介绍的技术求解相应的多体问题. 这种方法不受符号问题困扰, 因为反对称性被直接编码进 Hamiltonian 的各项. 不过, 它最终仍受制于所得自旋问题的难度; 该问题可能含有复杂的非局域相互作用.

考虑作用于格点 j 的费米子湮灭算符和产生算符, 分别记为 $\hat{c}_j$ 和 $\hat{c}_j^\dagger$. Jordan–Wigner 变换规定

$$\hat{c}_j = \left(\prod_{k=1}^j \hat{\sigma}_k^z \right) \hat{\sigma}_j^-, \quad (5.45)$$

$$\hat{c}_j^\dagger = \left(\prod_{k=1}^j \hat{\sigma}_k^z \right) \hat{\sigma}_j^+. \quad (5.46)$$

其中, $\hat{\sigma}_j^\pm = \frac{1}{2}(\hat{\sigma}_j^x \pm i\hat{\sigma}_j^y)$ 表示自旋升降算符. 变换中的第一项给出一个相位; 它可以取 ± 1 , 取决于格点 $k = 1, \dots, j$ 上被占据的费米模式数是偶数还是奇数. 利用关系 $\hat{\sigma}_j^z = 2\hat{\sigma}_j^+ \hat{\sigma}_j^- - 1$ 和 $\hat{\sigma}_j^+ \hat{\sigma}_j^- = \hat{c}_j^\dagger \hat{c}_j = n_j$, 可以方便地重写这一项. 这保证所得算符满足费米反对易关系.

例如, 利用这一变换, 可以把描述一维自由费米子的 Hamiltonian

$$\hat{H} = -\frac{1}{2} \sum_j \hat{c}_j \hat{c}_{j+1}^\dagger + \hat{c}_j^\dagger \hat{c}_{j+1} \quad (5.47)$$

映射为如下形式的相互作用自旋 Hamiltonian:

$$\hat{H} = -\frac{1}{2} \sum_j \hat{\sigma}_j^+ \hat{\sigma}_{j+1}^- + \hat{\sigma}_{j+1}^+ \hat{\sigma}_j^-. \quad (5.48)$$

在这种形式下, 可以实施章 5 介绍的全部方法.

这一变换的主要问题, 是它不能很好地推广到任意维数. 在高维中, Jordan–Wigner 变换会产生非局域自旋 Hamiltonian, 多数标准技术无法处理. 人们已经提出了适用于高维费米自由度的不同映射; 它们不是通用映射, 而是针对特定问题定制的. 例如, 对某些特定规范理论, 可以把一维以上的局域 Hamiltonian 映射为局域玻色 Hamiltonian [298, 299]. 文献 [300] 还考虑了另一种利用辅助体系 (ancillary system) 避免高维非局域自旋 Hamiltonian 的方法. 在这种方法中, Ansatz 的自由度被分成主体系和辅助体系; 代价是扩大 Hilbert 空间, 而收益是能从局域费米 Hamiltonian 构造局域自旋 Hamiltonian.

计算分子的电子结构 (electronic structure) 是当前一个重要的费米子问题, 对化学应用尤为关键 [247]. 它是量子多体问题最早的实例之一, Dirac 在 1929 年便已提




图 5.8: 不同方法给出的 (a) C_2 与 (b) N_2 分子基态能量 (单位为 Hartree, Ha) 随核间距的变化, 并与含 $M = 40$ 个隐藏单元的受限 Boltzmann 机 Ansatz 结果比较. CCSD(T): 耦合簇 (coupled-cluster) 方法; FCI: 完全组态相互作用 (full-configuration interaction); 图取自文献 [247].

及 [245]. 在这一语境中, 人们通常关心基态能量如何依赖某个物理参数, 例如双原子分子的两核间距. 通过寻找能量的极小值, 可以确定目标分子的稳定几何结构.

相互作用费米 Hamiltonian 通常定义在晶格上, 具有如下形式:

$$\hat{H} = \sum_{i,j} t_{ij} \hat{c}_i^\dagger \hat{c}_j + \sum_{i,j,k,l} U_{ijkl} \hat{c}_i^\dagger \hat{c}_j^\dagger \hat{c}_k \hat{c}_l. \quad (5.49)$$

其中, t_{ij} 是单体跃迁项, U_{ijkl} 是二体相互作用强度, 而 $\hat{c}_i$ ($\hat{c}_i^\dagger$) 是模式 i 的费米湮灭 (产生) 算符.¹³ Jordan-Wigner 变换把这一 Hamiltonian 化为

$$\hat{H} = \sum_r a_r \mathbf{S}_r. \quad (5.50)$$

其中, a_r 是标量系数, $\mathbf{S}_r$ 是 Pauli 串 (Pauli string), 由单量子比特算符集合 $\{\mathbb{I}, \hat{\sigma}^x, \hat{\sigma}^y, \hat{\sigma}^z\}$ 中的元素组成. 换言之, 现在得到的是一个相互作用自旋问题. 虽然所得 Hamiltonian 不一定是 k -局域的, 但可以证明其局域能量仍能高效估计. 因此, 这些映射适合用神经网络量子态作变分搜索.

本领域另一项近期进展, 是为费米子构造节 2.4.6 介绍的显式自回归 Ansatz [301]. 这里考虑由 M 个空间轨道组成的一组自旋轨道 (spin-orbital) 基, 每个空间轨道都有向上和向下两种自旋; 也就是说, 该基由 $|\mathbf{x}_k\rangle = |x_k^{1\uparrow}, x_k^{1\downarrow}, x_k^{M\uparrow}, x_k^{M\downarrow}\rangle$ 张成. 每个空间轨道可以作为一个独立单元, 取四个可能值之一, 记为 v_k^i . 因而, 相应波函数系数的对数具有如下形式:

$$\ln \psi_k = \sum_{j=1}^M \ln |\psi_j(v_k^j | v_k^1 \dots v_k^{j-1})| + i\phi_j(v_k^1 \dots v_k^M). \quad (5.51)$$

只要条件振幅 ψ_i 已归一化, 这一形式就能保证波函数正确归一化, 因而允许直接采样并带来更好的结果.

¹³可以在实空间基底或动量空间基底中表述该问题; 为保持一般性, 这里不作指定.

最后，图 5.8 展示了神经网络量子态用于费米子体系所得的物理结果。图中给出多种数值方法得到的 C_2 和 N_2 分子解离曲线，即基态能量随核间距的变化。利用受限 Boltzmann 机 Ansatz 和简单的 Jordan–Wigner 变换，可以恢复与近期完全组态相互作用计算相媲美的结果，显示出神经网络量子态的通用性与强大能力。

5.3.5 量子电路的经典模拟

神经网络量子态的另一个大有希望的方向，是对量子电路 (quantum circuit) 作经典模拟；我们将在节 8.2.1 介绍量子电路。事实上，目前用于大型量子电路（至少约含 50 个量子比特）的经典模拟方法依赖张量网络方法，而这类方法明确受纠缠限制。尤其是，张量网络态无法捕捉量子电路中迅速出现的体积律纠缠标度，而深度卷积神经网络等某些神经网络量子态架构可以做到 [270]。在这一语境中，可以从两个略显正交的方向研究神经网络量子态：一方面，可用量子电路探测其容量和可训练性的极限；另一方面，可用神经网络量子态推进量子硬件的经典模拟极限。

考虑由 D 个量子门 (quantum gate) 组成的集合 $\mathcal{G} = \{\hat{G}_i\}_{i=1}^D$ 所定义的量子电路，其中每个门由幺正算符 (unitary operator) $\hat{G}_i$ 定义。每施加一个门后，都必须更新变分态，以捕捉前一个门的作用。因而，对每个门都必须最小化如下变分距离：

$$\mathcal{L}(\tilde{\theta}) = \text{dist} \left(|\Psi_{\tilde{\theta}}\rangle, \hat{G}_i |\Psi_{\theta}\rangle \right), \quad (5.52)$$

其中， $\tilde{\theta}$ 是待优化参数， θ 是前一个变分态的参数， $\hat{G}_i$ 是与门 G 对应的幺正算符（例如对 NOT 门有 $\hat{G}_i = \hat{\sigma}^x$ ）。可以对每个门 G 应用这一过程，并在 D 次优化后得到电路末端的输出态。注意， $\hat{G}_i$ 必须是 k -局域门，否则无法执行最小化过程（这与基态搜索的情形相似）。这很少构成问题，因为只用单量子比特门和双量子比特门就能构造通用门集 (universal gate set)。在这一条件下，最小化式 5.52 与基态优化非常相似。利用非保真度展开这一表达式（见式 5.38），可得

$$\mathcal{L}(\tilde{\theta}) = 1 - \left\langle G_{\text{loc}}(\theta, \tilde{\theta}) \right\rangle_{|\Psi_{\tilde{\theta}}|^2} \left\langle G_{\text{loc}}(\tilde{\theta}, \theta) \right\rangle_{|\Psi_{\theta}|^2} \quad (5.53)$$

$$\text{其中 } G_{\text{loc}}(\theta, \tilde{\theta})(s) = \sum_{s'} \frac{\langle s | \hat{G}_i | s' \rangle}{\Psi_{\tilde{\theta}}(s)} \Psi_{\theta}(s'), \quad (5.54)$$

这里把 G_{loc} 定义为局域估计量，与基态搜索中介绍的过程类似。与机器学习中常见的情形一样， $\mathcal{L}(\tilde{\theta})$ 的最小化可能不够精确，从而降低模拟的总体保真度 (fidelity)。不过，采用受限 Boltzmann 机架构时，并非所有门都必须通过最小化上述损失来近似。某些门可以“解析地”施加；也就是说，可以找到网络参数的精确更新，使之与所施加的门相匹配。一般而言，不可能对通用门集中的所有门实现这种精确更新，否则只需获得每个门对应的精确参数更新，就能用受限 Boltzmann 机以无限精度模拟任意量子电路。

例如，考虑作用于自旋 s_j 的 Z 门，其算符定义为 $\hat{G} = \hat{\sigma}_j^z$ 。该算符作用于基态 $|s\rangle$ 的结果就是 $\hat{G}|s\rangle = (-1)^{s_j} |s\rangle$ 。施加门之前的受限 Boltzmann 机参数定义为 $\theta = (\mathbf{b}_v, \mathbf{b}_h, \mathbf{W})$ ，施加门之后的参数定义为 $\tilde{\theta} = (\tilde{\mathbf{b}}_v, \tilde{\mathbf{b}}_h, \tilde{\mathbf{W}})$ 。参数更新由下列方程的解

给出，其中 C 为常数：

$$\Psi_{\tilde{\theta}}(s) = C \langle s | \hat{G} | \Psi_{\theta} \rangle \quad (5.55)$$

$$\exp(\tilde{b}_{v,j} s_j) = C (-1)^{s_j} \exp(b_{v,j} s_j), \quad (5.56)$$

取 $C = 1$ ，可直接得到 $\tilde{b}_{v,j} = b_{v,j} + i\pi$. 上式能够化简，是因为该门在受限 Boltzmann 机振幅的其他部分上作用平凡；振幅的定义见节 5.2.1. 关于解析施加其他门的细节，见文献 [302] 和文献 [303]. 后一篇文献使用受限 Boltzmann 机 Ansatz，对量子近似优化算法（quantum approximate optimization algorithm, QAOA）[304]¹⁴ 对应的电路作经典模拟. 这种量子算法可以求解某一类组合优化（combinatorial optimization）问题. 相应电路很浅，可在当前硬件上实现 [305]. 从图 5.9 可以看出，利用受限 Boltzmann 机 Ansatz 模拟量子电路所得的结果与精确模拟非常接近，因而能够求解大型体系的优化问题. 作者还估计，与张量网络方法相比，该方法具有显著优势.¹⁵ 事实上，从图 5.9 左图可以看出，采用矩阵乘积态时，要达到与受限 Boltzmann 机相同的结果，所需键维数会很快增大到令人望而却步的程度.

另一种方案由文献 [306] 的作者提出，他们使用 Transformer (transformer) 架构模拟量子电路. Transformer 是一种采用自注意力 (self-attention) 机制的深度学习模型，它以不同权重衡量输入数据各部分的重要性 [307]. 文献 [306] 利用这一框架，引入了一种以 Transformer Ansatz 模拟量子电路的实用算法；Transformer 正是近年来自然语言处理取得突破的架构. 该框架能够模拟制备多达 60 个量子比特的 Greenberger–Horne–Zeiling 态 (Greenberger–Horne–Zeiling state) 和线性图态 (linear graph state) 的电路.




图 5.9: 在 3-平面图上对量子近似优化算法进行经典模拟的结果. (a) 给出不同 p 值下的近似代价函数 $\langle C \rangle$ ，其中 p 是量子电路深度. 虚线对应 $p = 1$ 量子电路的精确模拟，本任务中的受限 Boltzmann 机模拟准确复现了该结果. (b) 估计在量子近似优化算法电路的矩阵乘积态模拟中，要达到受限 Boltzmann 机的精度所需的键维数. 对 $N = 54$ 个量子比特，所需键维数约为 10^4 ，相当于使用数十亿个参数，而受限 Boltzmann 机只使用数百个参数. 图取自文献 [303].

¹⁴量子近似优化算法是一种用于处理组合优化问题的变分量子算法.

¹⁵这一估计基于数值模拟数据的外推.

5.3.6 开放量子系统

用神经网络表示量子态的思想也已应用于开放量子系统 (open quantum system). 开放量子系统是与环境 (environment) 相互作用的物理系统, 例如与电磁场相互作用的原子阵列. 人们通常并不描述完整的体系与环境整体, 而只关心体系本身的性质 (在上述例子中即原子), 并仅保留体系与环境相互作用的有效描述 (环境在该例中为电磁场). 这种描述使人们能够理解退相干 (decoherence) 等效应. 在Born–Markov 近似 (Born–Markov approximation) 下, 开放量子系统的时间演化由Lindblad 主方程 (Lindblad master equation) 给出 [308]:

$$\partial_t \hat{\rho} = -i[\hat{H}, \hat{\rho}] + \sum_{i=1}^D \left(\hat{J}_i \hat{\rho} \hat{J}_i^\dagger - \frac{1}{2} \{ \hat{J}_i^\dagger \hat{J}_i, \hat{\rho} \} \right) \equiv \mathbf{L}[\hat{\rho}]. \quad (5.57)$$

其中, $\hat{\rho}$ 是体系的密度算符 (density operator), $\hat{H}$ 是体系 Hamiltonian ($\hbar = 1$), $\hat{J}_i$ 是描述体系与环境相互作用的所谓跳跃算符 (jump operator). 这里还定义了Liouvillian (Liouvillian) $\mathbf{L}$; 对开放量子系统而言, 它所起的作用相当于 Hamiltonian 对封闭量子系统的作用 (相差一个 i), 即充当时间演化生成元. 许多工作关注满足 $\mathbf{L}[\hat{\rho}] = 0$ 的稳态 (steady state) $\hat{\rho}$, 或特定体系的动力学; 后一问题通常要求像处理封闭体系的非平衡动力学那样, 对式 5.57 作时间积分.

首先遇到的困难, 是如何用神经网络正确表示 $\hat{\rho}$. 事实上, 密度矩阵 (density matrix) 比波函数更难表示, 因为它必须是Hermitian (Hermitian)、半正定 (positive semidefinite) 且迹为 1. 目前仍未找到把密度矩阵编码进任意神经网络的一般方法. 这些工作的关键在于, 密度矩阵总能被纯化 (purification), 其矩阵元可写为

$$\langle s | \hat{\rho} | s' \rangle = \sum_{s''} \Psi(s, s'') \Psi^*(s'', s'). \quad (5.58)$$

其中, $\Psi(s, s')$ 是属于联合 Hilbert 空间的纯化; 该空间由体系和一个虚构辅助体系组成, 辅助体系的 Hilbert 空间维数至少与体系相同. 采用受限 Boltzmann 机架构时, 可以用神经网络编码纯化 $\Psi_\theta(s, s')$, 并利用该架构解析地迹掉辅助自旋 s' , 而不必显式执行通常需要指数多次运算的求和. 细节见文献 [309, 310, 311, 312].

第二种较新的方案, 是把密度矩阵视为正算符值测度 (positive operator-valued measure, POVM) 上的概率分布, 并用循环神经网络、自回归神经网络等一般密度估计模型表示所得分布. 在这种形式体系中, 密度矩阵可直接写成

$$\hat{\rho}_\theta = \sum_a p_\theta(a) \hat{M}_a. \quad (5.59)$$

其中, $\hat{M}_a$ 是从某个完备正算符值测度集合中选取的正算符值测度. 例如, 它们可以由 Pauli 算符和单位算符作张量积得到的全部算符. 在这一图景中, 只需用神经网络编码概率分布 $p_\theta(a)$. 这种基于正算符值测度的表示源于如下事实: 密度矩阵可视为 4^N 次测量的系综; 朴素的实验量子层析正是以这种方式重建密度矩阵. 该方法缓解了开放体系只能使用受限 Boltzmann 机的限制, 却不能保证密度矩阵为正, 因而可能产生非物理态. 尽管如此, 采用正算符值测度编码的一些结果仍颇具前景 [313, 314]; 理解它们在哪些区域表现最好, 是一个关键研究方向.

寻找开放量子系统的稳态既困难又有意义；困难在于需要对角化的 Liouvillian 规模极大（对含 N 个自旋的体系为 4^N ），意义则例如体现在研究耗散相变（dissipative phase transition）上 [315]. 构造密度矩阵的参数化 $\hat{\rho}_\theta$ 后，只需最小化如下代价函数：

$$\mathcal{L}(\theta) = \langle \hat{\rho}_\theta \mathbf{L}^\dagger \mathbf{L} \hat{\rho}_\theta \rangle. \quad (5.60)$$




图 5.10: 在由横场 Ising Hamiltonian 和跳跃算符 $\hat{J}_i = \sqrt{\gamma} \hat{\sigma}_i^-$ 描述的开放体系稳态下，可观测量 $\hat{\sigma}_k = 1/N \sum_i \hat{\sigma}_i^k$ ($k \in \{x, y, z\}$) 的期望值随 g/γ 的变化，其中 g 为磁场强度. 图中同时给出纯化受限 Boltzmann 机方案和采用 Transformer 网络的正算符值测度方案. 图取自文献 [313].

所得态对应于 Liouvillian 的零本征值为零的情形，即稳态. 关于具体过程和梯度求法的细节，见文献 [311, 312, 310, 309]. 从图 5.10 可以看出，该方法已应用于横场 Ising 模型的耗散版本；无论采用正算符值测度方案还是受限 Boltzmann 机方案，结果都很好. 在前一种情形中，网络具有更强的表达能力，但没有强制密度矩阵为正. 对每种方案在何时失败、何时成功，目前仍缺乏清晰认识；这是一个重要研究方向.

这里没有详细介绍开放量子系统的动力学，但随机重构同样可用于开放体系中的受限 Boltzmann 机 [312] 和正算符值测度 [314] 方案.

5.3.7 量子态层析

未来的量子技术以相干性、纠缠或 Bell 非定域性等量子资源为基础. 主要挑战之一，是通过实验认证给定未知量子态是否具有这些性质 [316, 317, 318, 319, 320, 321, 322, 323, 324, 325, 326, 327].

量子资源的信息编码在态的密度矩阵中，而密度矩阵只能依据有限统计测量来重建；这一过程称为量子态层析（quantum state tomography）[328, 329, 330, 331, 332, 333, 334, 335, 336, 337, 338]。密度矩阵重建是一项困难任务：随着体系增大，所需测量数呈指数标度。人工神经网络已经进入量子态层析领域，并提出了监督式深度学习方案[339, 340, 341, 342, 343, 344]。以下各段介绍神经网络辅助量子态层析的基本概念。

量子态层析是依据有限统计测量数据重建密度矩阵的过程。由于 Hilbert 空间随体系大小增大而指数增长，所需测量数也呈指数标度。然而，借助深度神经网络，可以用多项式数量的测量完成密度矩阵重建。

考虑这样一个任务：在由 $|s\rangle = |s_1, s_2, \dots, s_N\rangle$ 张成的某个基中作投影测量，由所得有限数量的快照 $|\psi(s)|^2$ 重建波函数 $|\psi\rangle$ ；其中 s_i 是某个局域量子数， N 是体系大小。用神经网络量子态的语言，这一任务就是最小化

$$\min_{\theta} \text{dist}(|\psi_{\theta}\rangle, |\psi\rangle). \quad (5.61)$$

这里， θ 是一组变分参数， $|\psi_{\theta}\rangle$ 是待优化的变分态，由神经网络参数化。此处不限定网络架构；只要能高效训练，任何架构都可采用。可以考虑多种距离，但这里关注 Torlai 等人 [345] 最先采用的 Kullback–Leibler 散度（见节 2.3）。对定义在同一空间 $\mathcal{P}$ 上的两个概率分布 p 和 q ，它定义为

$$D_{\text{KL}}(p||q) = \sum_{x \in \mathcal{P}} p(x) \log \frac{p(x)}{q(x)}. \quad (5.62)$$

将它用于量子态很直接，因为可以由 Born 规则得到概率分布，即 $p_{\theta}(s) = |\psi_{\theta}(s)|^2$ 、 $q(s) = |\psi(s)|^2$ 。令 x 为某个快照集合 S 中的构型 s ，便可以最小化

$$D_{\text{KL}}(\theta) = \sum_{s \in S} |\psi_{\theta}(s)|^2 \log \frac{|\psi_{\theta}(s)|^2}{|\psi(s)|^2}, \quad (5.63)$$

由此得到一种可能的方案。

不过要记住，量子态并不只是概率分布。从量子态**总能**定义概率分布，但反过来**不成立**。更明确地说，我们希望重建完整量子态，其振幅为 $\psi(s) = \sqrt{Q(s)}e^{i\phi(s)}$ 。最小化式 5.63 时，**相位信息 $\phi(s)$ 会丢失**。这一区别至关重要，也是学习量子态时许多问题的核心。正如章 5 所述，学习受挫量子态的相位颇具挑战 [346]。

这一问题的优雅解法是**考虑在不同基中进行的测量**。量子态在另一个基中的形式涉及不同基中振幅之间的干涉。因而，只要这些基包含关于量子态的足够信息，使不同测量基中的快照所定义的概率分布彼此匹配，就能得到正确的量子态。在数学上，只需把式 5.63 替换为

$$D_{\text{KL}}(\theta) = \sum_B \sum_{s \in S_B} |\psi_{\theta}^B(s)|^2 \log \frac{|\psi_{\theta}^B(s)|^2}{|\psi^B(s)|^2}. \quad (5.64)$$

其中， S_B 是量子态在基 B 中的快照集合， $\psi^B(s) = \langle s | \hat{U}_B | \psi \rangle$ ， $\hat{U}_B$ 是酉算符。随后可像通常一样用自动微分求梯度；对受限 Boltzmann 机等简单模型，也可解析求得梯度。

图 5.11 给出了合成态与重建态的多种可观测量. 合成态近似三角晶格 Heisenberg 模型的基态, 相关工作的作者利用张量网络模拟生成了该态 [91]. 重建态采用本节介绍的思想与循环神经网络架构得到 (更多细节见引言或章 5 与节 7.2), 并使用量子态的正算符值测度表示 (更多细节见节 5.3.6). 注意, 这一方案已经推广到混合态重建 [347]; 不过, 与上文所述类似, 还需格外小心, 避免重建密度矩阵的正性问题.




图 5.11: 三角晶格上含 $N = 50$ 个自旋的 Heisenberg 模型基态所对应的多种可观测量. (a) 每个自旋 i 沿 x 方向的平均磁化强度. (b) 格点 1 上的自旋与格点 i 上自旋之间的自旋-自旋关联函数. (c) 与 (d) 第一个自旋与第 i 个自旋之间的平均自旋-自旋关联. 可以看到, 所有可观测量都以很高精度得到复现. 改编自文献 [91].

在实验上, 可以通过施加旋转 (例如使用激光脉冲) 再对体系作重复测量来实现这一策略. 文献 [348] 的作者采用受限 Boltzmann 机架构, 首次展示了如何由可编程 Rb 原子阵列的实验数据重建量子态. 其中, 波函数在 $\hat{\sigma}^z$ 基中的快照通过格点分辨荧光成像获得. 使用真实数据时会遇到测量误差引入的噪声, 使快照集合 $|\psi(s)|^2$ 与体系状态不能完美匹配. 该工作在神经网络中加入噪声层, 在训练期间变换快照以滤除噪声, 从而处理这一问题. 代价是增加网络参数总数, 但这仍是一种快速而简便的实验噪声处理策略, 能够实现高保真度的量子态重建. 自神经网络量子态量子层析提出以来, 人们

已为将其用于真实实验付出大量努力。有关这类方案的实验挑战，更多细节可参见文献 [349, 350, 351, 352, 353]。

这些方案背后的基本原理是：用多项式数量的基 B 和多项式数量的快照，应当能够重建属于某一类别的态，例如不包括几乎没有任何结构的完全随机态。如前所述，这一类别的确切范围尚不清楚，正是当前研究的课题。类比图像，图像并非完全随机，而包含大量隐藏结构；设计和训练得当的神经网络能够学习这些结构。人们希望量子态也是如此；研究这类技术的极限，还有望帮助我们更细致地理解量子态的隐藏结构，超越通过研究张量网络的纠缠性质已经得到的认识。

最后介绍一种随机测量技术：它无需重建完整量子态，就能预测自旋-1/2 量子系统的若干选定性质，即所谓的“影子层析” (shadow tomography) (见文献 [354, 240, 355, 356, 357, 358, 359, 360])。影子层析依据重复测量所收集的数据估计给定可观测量的期望值，其中每个自旋的测量基均随机选取。然而，所需测量数随待重建算符平均值的局域性呈指数标度，尽管其运行时间通常仍优于从数据直接朴素测量这些可观测量。与此不同，本节考虑的是用有限数量的测量，训练完整波函数的低维表示。

5.4 展望与开放问题

我们希望以上材料足以推动神经网络量子态这一蓬勃发展领域中的进一步研究。下面列出与上述讨论有关的一些开放问题与挑战；这份清单并不穷尽：

- **神经网络量子态的容量。** 一些工作已经证明，神经网络量子态能够表示体积律纠缠，这意味着在强关联体系以及二维、三维体系中，它们可能优于张量网络态 [261, 270, 271]。另一些工作则证明，受限 Boltzmann 机与矩阵乘积态等价，意味着前者不能表示比后者更多的态 [262]。尽管已经得到一般性定理，人们对具体架构的认识仍很有限；理解不同架构分别在哪些问题上表现更好，是一个关键问题。此外，证明表示能力并不意味着模型能够得到高效训练，因此理解神经网络量子态模型的训练机制十分重要。
- **长时间动力学。** 由于随机重构存在稳定性问题，长时间动力学对神经网络量子态而言仍是一个相对较少探索的领域 [288]。不过，正则化技术已经带来了一些进展 [267]。一些工作提出最小化非保真度 [287, 361]，从而在随机重构表现不佳的区域超越该方法。文献 [362] 解释了时间演化中出现的一种系统偏差；这应能推动长时间动力学研究，因为神经网络量子态对大晶格的相关结果仍然十分欠缺。
- **开放量子系统。** 目前尚未找到把密度矩阵编码到任意神经网络中的一般方法；人们要么只能采用具有已知局限的受限 Boltzmann 机，要么采用可能因密度矩阵非正而失效的正算符值测度方案。
- **受控系统。** 事实证明，以神经网络量子态方法寻找受控系统的基态颇具挑战 [346]。如何改进这一过程的优化，以学习具有非平凡符号结构的相位，尤其值得深入研究。

- **量子电路模拟.** 除受限 Boltzmann 机外，采用其他网络得到的结果还很少。研究不同电路如何影响所选 Ansatz 的精度，可以从两方面产生结果：理解给定电路的复杂度，以及理解所选 Ansatz 的局限。
- **量子态层析.** 基于神经网络的量子态层析仍处于起步阶段。迄今为止，人们只在玩具模型和小型实验环境中作过数值探索，而在这些情形下，传统量子态层析仍然可行。它的真正优势很可能在估计量子模拟中的困难物理量时显现。在这种情况下，估计之所以复杂，是因为即使能量和其他关联函数等简单物理量也可能具有很高的方差。这意味着其中一些物理量的样本复杂度 (sample complexity) 可能随体系大小迅速增长。
- **量子资源认证.** 可以利用单轴扭转 (one-axis twisting) 协议动态生成量子资源 [363, 364]。单轴扭转可在光晶格中的超冷原子体系中实现，用来生成多体纠缠与多体 Bell 关联 [365, 366, 367, 368, 369, 370]。这项技术的挑战，是验证多量子比特体系中生成的量子资源；深度学习可以帮助完成这一任务 [344]。
- **推广到连续 Hilbert 空间与玻色体系.** 目前，大多数技术与工作都聚焦于具有离散自由度的体系，例如自旋体系。人们已经研究了向连续 Hilbert 空间的推广，例如量子化学 [293, 294, 295] 和核物质 [371] 中的应用。对玻色 Hilbert 空间进行高效编码，对于通常采用类似平均场方法处理的光子体系等也会特别有意义。
- **量子信息中的应用.** 如前所述，神经网络量子态已经用于模拟量子电路。它们也已用于量子纠错和量子通信中的量子码 (quantum code) [372]。在该文中，作者证明，可以根据物理体系所经受的噪声信道，用神经网络量子态学习高效量子码。神经网络量子态在量子信息中的应用尚不广泛；我们预计，未来几年它们将成为这一领域的有用工具。

延伸阅读

- Carleo, G. & Troyer, M. (2017). *Solving the quantum many-body problem with artificial neural networks*. Carleo 与 Troyer 引入神经网络量子态的开创性论文 [246]。
- Becca F. and Sorella, S. (2017). *Quantum Monte Carlo Approaches for Correlated Systems*. 一部内容全面的专著，包含量子 Monte Carlo 方法和变分态的详细介绍 [290]。
- Vicentini, F. et al. (2021). *NetKet 3: Machine learning toolbox for many-body quantum systems*. 开源程序库 NetKet 3 的配套论文，其中广泛讨论了如何实现本章介绍的多种算法，并提供了一组教程，说明如何用神经网络量子态求解若干基准问题 [284, 373]。
- Carrasquilla, J. & Torlai, G. (2021). *How to use neural networks to investigate quantum many-body physics*. Carrasquilla 与 Torlai 撰写的一篇较新教程，其中包含有趣的应用和代码片段，可以帮助希望进入这一领域的读者 [97]。
- Carleo, G. (2017). *Repository for example codes presented at the “Machine Learning and Many-Body Physics” workshop*. 2017 年北京 “Machine Learning and Many-Body Physics” 研讨会制作的讲义、习题和代码 [374]。

强化学习

到目前为止，我们已经见过多种机器学习情形，其中包含监督或无监督学习问题；我们的目标是推断某些标签、预测某些数值，或在数据中寻找模式。本章介绍一种不同的方案：**学习策略**。

在监督学习框架下，可以把学习者想成一名学生：教师知道给定领域内所有可能问题的正确答案，学生则向教师学习。在这种方案中，学生受教师知识所限，既不可能超越教师，也无法处理教师专长以外的问题。为克服这一局限，在强化学习中，我们移除教师，让学生亲自尝试，并从所得经验中学习。我们把这名学生称为智能体 (agent)，因为它能够主动采取行动。与人类一样，智能体通过同**环境**交互来学习，理解自身行动的后果，并寻找实现特定目标的策略。

例如，考虑教一个智能体下国际象棋。监督学习方案会训练一个机器学习模型，复现世界顶尖棋手的棋局记录中的走法。在这一设定下，给定一个棋局状态，即棋盘上剩余棋子的位置，模型预测这些参考棋手会选择的走法。然而，这一方案存在若干重大缺陷。例如，并非每种局面都存在唯一的最优走法，而且走法强烈依赖棋手采用的棋局策略。因此，智能体可能无法通过一系列行动始终如一地贯彻某种策略。此外，智能体的表现最终受训练数据质量限制，这意味着它可能无法超越参考棋手。相关例子见[节 6.6.2](#)。

另一种做法，是除了规则以外不提供任何额外知识，让智能体与不同对手甚至与自己对弈。在这种情况下，它会形成自己对棋局的理解，并设计自己的策略。所得智能体的潜力远大于前一种方案，因为它不受教师限制。尽管如此，从经验中学习仍可能颇具挑战：行动质量只在棋局结束、胜负确定时才能得到评价。¹ 因此，智能体必须依据来自环境的稀疏反馈，深入理解行动的长期后果。

把问题表述成游戏以发现策略，有不计其数的应用。控制问题尤其自然地适合这一框架。不过，我们还可以设计游戏，以获得任何感兴趣的协议或算法，从新的量子实验 [\[375\]](#)，到更快的矩阵乘法或排序算法 [\[376, 377\]](#)。本章将说明如何用强化学习处理量子技术领域中的若干典型问题。

本章介绍强化学习领域。首先在[节 6.1](#)中，从直观角度介绍从经验中学习这一概念及其数学基础。随后介绍两种主要方案：[节 6.2](#)中的基于价值的强化学习，以及[节 6.3](#)中的策略梯度。在[节 6.4](#)中，我们结合这两种范式，引入演员-评论家算法。接着在[节 6.5](#)中介绍另一种强化学习方案——投影模拟。最后，[节 6.6](#)给出一系列强化学习应用实例，既包括游戏中的超人类表现，也包括量子技术中的多种问题。

¹在某些情况下，我们可能想加入中间奖励，例如吃掉对方棋子时给予奖励。然而，这样做实际上改变了棋局及其目标，因此可能无法找到原问题的最优策略。

6.1 强化学习基础

任何强化学习问题的一般设定都由两个主要元素组成：智能体，以及与之交互的环境，如图 6.1 所示。环境包含定义当前问题的全部信息，例如游戏规则；并根据智能体的行动（action），向它提供观测和反馈。环境定义全部可能状态（state）的集合 $s \in \mathcal{S}$ 。对无状态环境而言，该集合可以是空集（见节 6.6.1 中的第一个例子）；它也可以是多维连续空间。例如，这些状态可以是棋盘游戏的全部可能布局，或机器人各关节角度的全部可能组合。

智能体能够观测环境的状态 s （有时只能作部分观测），并可选择要执行的行动 a ，其中也可能包括保持不动。行动从环境定义的可能行动集合 $a \in \mathcal{A}$ 中选取，而该集合可以依赖状态。例如，在国际象棋中，只有兵的前方位置为空时，才能执行把兵向前推进的行动。行动可能改变环境所处的状态，其结果可以是确定性的，也可以是随机的。在国际象棋例子中，所有行动都是确定性的。相比之下，对行走机器人而言，向前移动可能产生不同结果：它可能成功前进，也可能绊倒，甚至可能因障碍或故障而以一定概率原地不动。这些信息编码在环境中，智能体却未必能够访问。

尽管如此，每当智能体执行一个行动，环境都会向它提供新状态的观测，以及一个称为奖励（reward）的反馈信号 r 。奖励可以取任意数值，并可能依赖先前状态、新状态和所执行的行动。智能体的主要目标是在任务结束时使所得奖励最大；因此，奖励这一量定义了目标任务。所以，智能体完成目标任务或朝目标前进时会获得较高奖励，例如赢得比赛；执行有害或不良行动时则可能受到惩罚，例如输掉比赛。

任何强化学习问题的核心目标，都是学习使所得奖励最大的最优策略（optimal policy） π^* 。策略（policy）规定智能体在给定观测下采取哪些行动，从而定义智能体所遵循的方略。

一般而言，策略可以采取任何形式，后续各节将对此说明。例如，它可以是一张为每个可能状态指定最佳行动的表；也可以是一个机器学习模型，在给定状态后输出全部可能行动上的概率分布。不过，学得策略只适用于具体问题。图 6.1 概括了这里引入的强化学习设定之关键元素。

下面用两个例子来直观说明强化学习设定的主要元素。对章 6 中的国际象棋而言，智能体是其中一名棋手。环境为游戏规则、对手²以及对应于棋盘棋子位置的状态建模。³状态空间（state space）包含一局棋中能够到达的全部棋盘布局，例如排除某一方王不在棋盘上的布局。行动空间（action space）对应于每回合能够执行的全部合法走法。在这种情况下，棋局结束前智能体得不到奖励。棋局结束时，智能体胜利或失败会分别得到正奖励或负奖励；若战成平局，最终奖励可以为零，甚至可以为负。目标是学习能够带来尽可能多胜局的策略。

第二个例子是一台困在迷宫中的机器人。机器人只能看到紧邻环境，必须通过移动抵达目标位置。此时，智能体是机器人，环境则为迷宫、墙壁和目标位置建模。状态是智

²对手可以是同一个智能体，即智能体与自己对弈；但每个智能体都会把另一个视为各自环境的一部分。这称为自我博弈（self-play），有助于更快探索新策略。

³国际象棋状态还可以包含额外信息，例如当前是否仍可王车易位。为简化这个例子，这里只考虑棋子位置。




图 6.1: 强化学习基本设定的概览. 智能体从环境接收观测, 并根据该观测按照自身策略选择下一个行动. 环境决定行动的结果, 再向智能体返回由新状态和可能奖励组成的观测.

智能体当前位置及其紧邻环境, 状态空间由全部可达位置组成. 行动空间包含沿所有可能方向的移动, 而环境保证智能体不会穿墙. 因此, 向墙壁移动会使智能体留在原位, 不会改变状态. 在奖励方面, 可以在每次移动后给予智能体一个恒定的负奖励, 鼓励它用尽可能少的步数到达目标.

6.1.1 延迟奖励

如前所述, 奖励 r 是强化学习中的关键概念. 智能体学习使奖励最大化, 因此, 这一量定义了问题. 在给定的离散时刻 t , 智能体观测状态 s_t , 并按照其策略执行行动 a_t . 随后, 环境向智能体呈现新状态 s_{t+1} 和奖励 r_{t+1} . 因此, r 依赖时间, 并且可以依赖另外三个量中的任意一个, 即 $r_t = r(s_{t-1}, a_{t-1}, s_t)$ (更多细节见节 6.1.3).

到目前为止, 我们只简要讨论了如何使奖励最大化. 为了形式化强化学习目标, 需要引入延迟奖励 (delayed rewards) 的概念. 它们为智能体引入“向前看”的思想, 使其能够考虑沿状态空间中一条轨迹获得的未来奖励. 不过, 我们可以用折扣因子 (discount factor) $\gamma \in [0, 1]$ 惩罚遥远未来的奖励.




图 6.2: 折扣因子 γ 对强化学习算法的影响. (a) 短视算法 ($\gamma \rightarrow 0$) 可能满足于一种贪心策略, 该策略会带来较早的即时奖励, 即使它们小于后来可能得到的奖励. (b) 然而, 面向长期的算法 ($\gamma \rightarrow 1$) 可能牺牲早期奖励, 以换取更大的晚期奖励.

折扣因子按照奖励在时间上的间隔为其赋予权重. 这样, 即时奖励的权重大于遥远未来的奖励. 强化学习的目标是使折扣回报 (discounted return) 最大; 折扣回报定义为未来奖励的加权和

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}, \quad (6.1)$$

它计入从时刻 t 起直至终止时刻 T 获得的奖励.^a

^a在强化学习中, 我们通常考虑有限轨迹. 不过, 折扣因子 $0 \leq \gamma < 1$ 使我们能够考虑回报有限的无限轨迹 $T = \infty$.

注意, 回报具有递归形式, 这对许多强化学习算法至关重要:

$$G_t = r_{t+1} + \gamma G_{t+1}. \quad (6.2)$$

这一概念受到人类心理学启发, 并模拟了我们的日常观察: 遥远未来的奖励即使很高, 也不如近期奖励令人向往, 例如, 我们宁愿拖延, 也不愿阅读本书. 可以区分两个极限: 当折扣因子很小, 即 $\gamma \rightarrow 0$ 时, 回报 (return) 变得短视, 也就是说, 即时奖励凌驾于其他任何可能的未来奖励之上. 另一方面, 大折扣因子, 即 $\gamma \rightarrow 1$, 会让早期奖励和晚期奖励具有相同权重, 从而鼓励面向长期的策略. 这尤其包括有意在开始时作出若干看似次优的选择, 而这些选择最终会带来大得多的回报. 图 6.2 描绘了这两种情形.

因此, 折扣因子强烈影响所得策略. 事实上, 它定义了强化学习任务, 因为智能体旨在使式 6.1 所引入的回报最大化. 尽管如此, 我们往往依靠试错法, 寻找最适合自身需求的折扣因子.

6.1.2 探索与利用

在强化学习中, 我们会遇到**探索**与**利用**之间的权衡. 为了使回报最大化, 智能体必须**利用**它关于良好策略的知识. 然而, 智能体也必须**探索**其他不同的行动, 以便改进它

们，甚至在未来发现更好的策略。

不过，学习算法不能只依赖探索，否则就会退化为蛮力搜索算法。相反，在纯利用的情形下，智能体会盲目坚持它找到的第一个可行策略，即使该策略远非最优。因此，我们需要在这两种机制之间找到平衡，使智能体能够尝试多种行动，并逐渐偏向最佳行动。这样，探索便围绕状态空间和行动空间中最有希望的区域展开，从而大幅减少智能体为找到最优策略而必须积累的经验量。

平衡探索与利用的一种常用策略是所谓的 ϵ -贪心策略 (ϵ -greedy policy)。在这种情况下，智能体按照其策略执行行动，即进行利用；同时，它可以在任意时刻以概率 $\epsilon \in [0, 1]$ 随机采取一个行动，即进行探索。这一方案涵盖两种范式：当 $\epsilon = 1$ 时为完全探索，而当 $\epsilon = 0$ 时为完全利用。调节 ϵ 即可在两种机制之间插值。一种常见做法是从较大的 ϵ 开始，以强化早期探索，再在训练过程中逐渐减小它。

6.1.3 Markov 决策过程

所有强化学习问题都由同一种底层数学结构建模，即Markov 决策过程 (Markov decision process, MDP)。它们构成一种通用框架，用于对状态之间具有序贯关系的环境建模。在这种环境中，给定现在以后，未来与过去无关。这称为Markov 性 (Markov property)。

本质上，Markov 性意味着当前状态是一个充分统计量 (sufficient statistic)，包含与环境可能演化有关的全部必要信息。特别地，先前访问过的状态不会产生任何记忆效应。形式上，在任意时步 t ,

$$p(s_{t+1} \mid s_0, \dots, s_t) = p(s_{t+1} \mid s_t). \quad (6.3)$$

在数学上，一个 MDP 是元组 $(\mathcal{S}, \mathcal{A}, p, G, \gamma)$ ，依次表示状态空间 $\mathcal{S}$ 、行动空间 $\mathcal{A}$ 、动力学 (dynamics) p 、总回报集合 G 和折扣因子 γ 。在这一形式体系中，回报 G 与折扣因子 γ 共同决定目标，而 p 描述环境动力学：

$$p(s', r \mid s, a) = p(s_{t+1} = s', r_{t+1} = r \mid s_t = s, a_t = a), \quad (6.4)$$

它对应于在状态 s 下执行行动 a 后，观测到新状态 s' 并获得奖励 r 的联合概率。对完全确定性的环境， $p(s', r \mid s, a)$ 不是零就是一。

由式 6.4 可以导出关于环境的全部相关信息。例如，状态转移概率 (state-transition probability) 是许多强化学习算法中的核心量：

$$p(s' \mid s, a) = \sum_r p(s', r \mid s, a). \quad (6.5)$$

此外，它还使我们能够确定奖励函数。在节 6.1.1 中，我们曾简要介绍奖励函数 $r(s, a, s')$ 。在最一般的形式下，如式 6.4 所示，奖励与状态 s' 联合确定。⁴ 不过，在许多情况下，我

⁴在随机环境中，奖励可以内在地从概率分布中采样。考虑二十一点游戏：在手牌相同（状态相同）时，停牌这一行动可能因对手手牌（环境）不同而得到不同奖励。因此，奖励是随机的。

们可能需要考虑状态-行动对以及状态-行动-下一状态三元组的期望奖励：

$$r(s, a) = \sum_r \sum_{s' \in \mathcal{S}} r p(s', r | s, a), \quad (6.6)$$

$$r(s, a, s') = \sum_r r \frac{p(s', r | s, a)}{p(s' | s, a)}. \quad (6.7)$$

在智能体与环境的迭代交互中，智能体按照策略选择行动。策略是从状态到执行每个可能行动之概率的映射：

$$\pi(a | s) = p(a_t = a | s_t = s). \quad (6.8)$$

在确定性策略的极限下， $\pi(a | s)$ 对某一个行动为一，对其余行动为零。

为了实现目标，策略利用智能体同环境交互所积累的经验得到改进。这一交互生成形如

$$s_0, a_0, r_1, s_1, a_1, r_2, s_2, a_2, \dots, s_T$$

的轨迹 (trajectory)，其中所有状态、行动和奖励都是随机变量。这样，智能体以概率

$$p(\tau) = \prod_{t=0}^{T-1} p(s_{t+1} | s_t, a_t) \pi(a_t | s_t), \quad (6.9)$$

沿状态-行动空间走过轨迹 $\tau = a_0, s_1, a_1, \dots, s_T$ ，并从初始状态 s_0 出发。与该轨迹相联系的折扣回报记为 $G(\tau) = \sum_{t=0}^{T-1} \gamma^t r_{t+1}$ 。

上述整个形式体系都以式 6.3 中的 Markov 性为假设；该性质意味着环境是无记忆的。不过，我们可能遇到环境具有某些记忆效应的情形，例如，在某些游戏中，执行一系列行动会在最后产生额外效果。在这些情况下，可以考虑一个已经包含记忆的扩展状态空间，以恢复 Markov 性。反过来，这意味着，即使完整状态空间上的 Markov 动力学是确定性的，它也可能在较小状态空间上产生非确定且非 Markov 的动力学。⁵

6.1.4 无模型强化学习与基于模型的强化学习

强化学习可以区分为两种主要范式：无模型强化学习 (model-free reinforcement learning) 和基于模型的强化学习 (model-based reinforcement learning)。在第一种设定中，智能体没有关于环境底层机制的任何信息，必须完全通过试错来学习。在第二种设定中，智能体要么能够访问环境模型 (model of the environment)，要么根据积累的经验构建一个模型。随后，智能体可以利用该模型向前规划，在执行任何行动之前推断一系列行动的结果，从而选择尽可能好的行动。

尽管本章其余部分关注无模型强化学习，我们仍会简要说明如何利用关于模型的知识。构建环境模型能使智能体更深入地理解问题，并可能帮助它应对新情形。例如，设一个智能体抛接一组球；若它拥有良好的物理定律模型，就会更容易学会抛接形状和重量不同的一组新球。

⁵讨论开放量子系统时会遇到类似情形：尽管系统及其热浴整体作么正演化，子系统中却会产生非么正动力学。

这些模型可以采取多种形式，而一种通用表述是完全可刻画的 MDP. 这样，模型近似问题底层 MDP 的动力学. 在某些情况下，真实模型过于复杂而难以掌握，此时可以只尝试近似动力学中与问题最相关的部分. 一个简单模型的例子是：在任意时步 t ，机器学习算法根据当前状态和行动 (s_t, a_t) ，同时预测期望下一状态和奖励 (s_{t+1}, r_{t+1}) . 给定当前状态以后，这种模型使我们能够预测一系列未来行动的结果；还可以直接利用智能体积累的经验，以监督方式训练它.

在连续行动空间中，模型在输入行动与所得奖励之间建立直接联系，使我们能够采用反向传播方法使回报最大化，而不只是从环境采样. 说明这一过程的例子见[节 7.1](#). 对离散状态空间，模型通常采用可供我们探索并加以利用的搜索树 (search tree) 形式. 当与环境交互的代价很高时，例如开展物理或化学实验，模型尤其便利. 在这些情况下，为了使总采样成本最小，我们会尝试用从模型抽取的人工样本来扩充由环境真实样本组成的数据集.

不过，我们并非总能访问模型，构建模型也可能不符合我们的利益. 构建模型代价高昂，尤其是在我们对环境所知有限时；而且模型只有足够准确才有帮助. 此外，模型往往针对特定问题定制. 相比之下，无模型强化学习算法的优势是不依赖当前具体问题，因而更为通用. 因此，出于教学目的，本章其余部分聚焦无模型强化学习，因为它们对整个强化学习任务范围都很有用. 具体而言，我们分别在[节 6.3](#) 和[节 6.2.1](#) 中介绍基于策略与基于价值的强化学习.

6.1.5 价值函数与 Bellman 方程

正如前几节所述，强化学习的目标是找到使[式 6.1](#) 所引入回报最大化的最优策略 π^* . 这一明确目标使我们能够定义价值函数 (value function)，用以估计智能体处于给定状态或执行某个行动对于完成任务有多合适. 例如，考虑在地图上寻找宝藏的情形. 总体而言，距离宝藏一步显然比距离十步好得多. 然而，在较近位置并非所有行动都同样好，因为其中一个行动通向宝藏，其他行动却会远离它. 这由智能体在当前条件下可能获得的期望未来回报来量化. 不过，由于未来奖励强烈依赖智能体将采取的行动，价值函数是相对于策略定义的.

策略 π 下状态 s 的状态价值函数 (state-value function) $V_\pi(s)$, 是在状态 s 出发并在此后遵循策略 π 时的期望回报. 形式上定义为

$$V_\pi(s) = \mathbb{E}[G_t \mid s_t = s, \pi] = \mathbb{E} \left[\sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1} \mid s_t = s, \pi \right]. \quad (6.10)$$

类似地, 行动价值函数 (action-value function) $Q_\pi(s, a)$, 是在状态 s 出发、执行行动 a 并在此后遵循策略 π 时的期望回报:

$$\begin{aligned} Q_\pi(s, a) &= \mathbb{E}[G_t \mid s_t = s, a_t = a, \pi] \\ &= \mathbb{E} \left[\sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1} \mid s_t = s, a_t = a, \pi \right]. \end{aligned} \quad (6.11)$$

优势 (advantage) $A_\pi(s, a)$, 是在状态 s 采取行动 a 相对于策略期望行为所获得的额外期望回报:

$$A_\pi(s, a) = Q_\pi(s, a) - V_\pi(s). \quad (6.12)$$

价值函数满足许多强化学习算法所利用的递归关系, 这一关系源于式 6.2 中回报的递归性质. 因此, 可以把状态价值函数 $V_\pi(s)$ 写成下一状态的函数:

$$\begin{aligned} V_\pi(s) &= \mathbb{E}[G_t \mid s_t = s, \pi] = \mathbb{E}[r_{t+1} + \gamma G_{t+1} \mid s_t = s, \pi] \\ &= \sum_a \pi(a, s) \sum_{s', r} p(s', r \mid s, a) (r + \gamma \mathbb{E}[G_{t+1} \mid s_{t+1} = s', \pi]) \\ &= \sum_a \pi(a, s) \sum_{s', r} p(s', r \mid s, a) (r + \gamma V_\pi(s')) \\ &= \mathbb{E}[r_{t+1} + \gamma V_\pi(s_{t+1}) \mid s_t = s, \pi]. \end{aligned} \quad (6.13)$$

对行动价值函数 $Q_\pi(s, a)$ 可以作类似推导:

$$\begin{aligned} Q_\pi(s, a) &= \mathbb{E}[G_t \mid s_t = s, a_t = a, \pi] = \mathbb{E}[r_{t+1} + \gamma G_{t+1} \mid s_t = s, a_t = a, \pi] \\ &= \sum_{s', r} p(s', r \mid s, a) (r + \gamma \mathbb{E}[G_{t+1} \mid s_{t+1} = s', \pi]) \\ &= \sum_{s', r} p(s', r \mid s, a) (r + \gamma V_\pi(s')) \\ &= \mathbb{E}[r_{t+1} + \gamma V_\pi(s_{t+1}) \mid s_t = s, a_t = a, \pi]. \end{aligned} \quad (6.14)$$

由此, 关系 $V_\pi(s) = \sum_a \pi(a \mid s) Q_\pi(s, a)$ 变得显然. 这些就是价值函数的 Bellman 方程 (Bellman equations); 它们处于强化学习的核心, 因为它们定义了状态 s 的价值与其后继状态 s' 的价值之间的关系, 以递归方式捕捉未来信息.

这些概念引入了策略之间的偏序 (partial ordering) 概念. 如果策略 π 产生的回报高于另一策略 π' , 则称 π 更好. 因此, $\pi > \pi'$ 当且仅当 $V_\pi(s) > V_{\pi'}(s) \forall s \in \mathcal{S}$. 于是, 最优策略 π^* 优于或等于所有其他可能策略.⁶ 因而, 最优策略使价值函数最大化. 根据

⁶策略之间并非总能定义序关系. 两个策略 π, π' 无法排序, 当且仅当 $\exists s, s' \in \mathcal{S} : V_\pi(s) > V_{\pi'}(s), V_\pi(s') < V_{\pi'}(s')$. 不过, 对 MDP 总存在一个最优策略 π^* , 使得 $\pi^* \geq \pi \forall \pi$ [378].

Bellman 方程式 6.13 和式 6.14, π^* 满足

$$\begin{aligned} V_{\pi^*}(s) &= \max_a \mathbb{E}[G_t \mid s_t = s, a_t = a, \pi^*] \\ &= \max_a \mathbb{E}[r_{t+1} + \gamma V_{\pi^*}(s_{t+1}) \mid s_t = s, a_t = a, \pi^*] \\ &= \max_a Q_{\pi^*}(s, a). \end{aligned} \quad (6.15)$$

注意, 在这一新的 Bellman 方程中, 对第一个行动作了最大化, 而不是像式 6.13 那样对行动取期望. 这是因为, 最优策略下一个状态的价值必须等于最佳行动的期望回报.

类似地, 可以求出最优策略 π^* 下行动价值函数 $Q_{\pi}(s, a)$ 的 Bellman 方程. 二者共同定义了 Bellman 最优性方程 (Bellman optimality equations):

$$\begin{aligned} V_{\pi^*}(s) &= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma V_{\pi^*}(s')], \\ Q_{\pi^*}(s, a) &= \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} Q_{\pi^*}(s', a') \right]. \end{aligned} \quad (6.16)$$

这些方程满足

$$\begin{aligned} Q_{\pi^*}(s, a) &= \max_{\pi} Q_{\pi}(s, a), \\ V_{\pi^*}(s) &= \max_{\pi} V_{\pi}(s) = \max_a Q_{\pi^*}(s, a). \end{aligned} \quad (6.17)$$

可以把给定状态 s 下的最优策略 $\pi^*(a \mid s)$ 和行动 a^* 定义为

$$\begin{aligned} \pi^* &= \arg \max_{\pi} V_{\pi}(s), \\ a^* &= \arg \max_a Q_{\pi^*}(s, a). \end{aligned} \quad (6.18)$$

按照最优行动价值函数 $Q_{\pi^*}(s, a)$, 最优策略 π^* 对应于在给定状态 s 确定性地选择最佳行动 a^* . 由于价值函数具有递归性质, 按照 V_{π^*} 或 Q_{π^*} 采取贪心行动在长期上是最优的.

Bellman 最优性方程式 6.16 确实构成一个方程组, 每个状态对应一个方程. 要直接求解它们, 需要显式使用 $p(s', r \mid s, a)$.⁷ 如果 $p(s', r \mid s, a)$ 已知, 我们就知道系统的底层模型, 因而处理的是上一节所讨论的基于模型的强化学习. 在一般的无模型强化学习情形中, 该量未知, 所以需要其他方法来求解这些方程, 例如以下各节将介绍的方法.

6.2 基于价值的方法

在基于价值的强化学习 (value-based reinforcement learning) 中, 目标是像式 6.18 那样, 通过学习最优价值函数来得到最优策略 $\pi^*(a \mid s)$. 为此, 从每个状态的价值函数 $V_{\pi}(s)$ 或状态-行动对的价值函数 $Q_{\pi}(s, a)$ 的初始估计开始, 再利用智能体遵循其策略所积累的经验逐步更新它们.

⁷由于式 6.16 中的最大化步骤, 这是一个非线性优化问题.

由于价值函数是相对于策略定义的（回顾节 6.1.5），需要为这一算法族规定一个固定策略。一种常见选择是节 6.1.2 中介绍的 ε -贪心策略，因为最优策略相对于最优价值函数是贪心的。因此，学习这种策略的价值函数，便能在贪心极限下得到最优价值函数。

学习价值函数的一种最直接而朴素的方法，是采样轨迹 $\tau \sim p(\tau)$ （式 6.9），随后用回报 G_t 更新沿途每个已访问状态 s_t 的价值函数估计⁸：

$$V_\pi(s_t) = V_\pi(s_t) + \eta(G_t - V_\pi(s_t)). \quad (6.19)$$

其中， η 是学习率。也可以对轨迹中每个已访问的状态和动作作类似处理，转而学习 $Q_\pi(s, a)$ 。

不过，这种方法只能在每条轨迹结束时学习；这样的轨迹也称为回合（episode）。对包含很长回合甚至无限回合的问题，这可能非常低效。相比之下，时序差分学习（temporal-difference learning, TD learning）算法利用价值函数的递归性质，即式 6.13 和式 6.14，在每个时步学习：

$$V_\pi(s_t) = V_\pi(s_t) + \eta(r_{t+1} + \gamma V_\pi(s_{t+1}) - V_\pi(s_t)). \quad (6.20)$$

注意， $V_\pi(s_t)$ 是估计量，而 $V_\pi(s_{t+1})$ 也是估计量。这称为自举（bootstrapping）方法，因为更新部分地以另一个估计量为基础。尽管如此，可以证明它收敛到唯一解。括号中的项称为时序差分误差（temporal-difference error, TD error）。

实现式 6.20 的算法称为 TD(0)，它是 TD(λ) 算法 [379] 的一个特例。行动价值函数的类似算法称为 SARSA（SARSA）[380, 381]：

$$Q_\pi(s, a) = Q_\pi(s, a) + \eta(r + \gamma Q_\pi(s', a') - Q_\pi(s, a)). \quad (6.21)$$

这里重新采用记号 s', a', r 表示下一状态、下一行动和奖励。若把 $Q_\pi(s', a')$ 替换为对下一步可能行动取的期望，例如 $\sum_{a'} \pi(a' | s') Q_\pi(s', a')$ ，便得到期望 SARSA（expected SARSA）算法 [382]。如果改为像下面的式 6.22 那样取最大值，便得到 Q-learning（Q-learning）[383]；下一小节节 6.2.1 将详细介绍它。

6.2.1 Q-learning

Q-learning 因其理想性质而成为最常用的时序差分算法之一 [383]。上一节介绍的大多数时序差分算法学习给定策略（主要是 ε -贪心策略）的价值函数。这些策略包含探索性的随机行动（回顾节 6.1.2），它们会影响学得的价值函数。因此，策略决定学习结果，我们必须在训练过程中调节 ε ，以确保价值函数适当地收敛到最优价值函数。然而，无论训练期间遵循何种策略，Q-learning 总是学习最优行动价值函数。⁹

目标是直接学习最优 Q 值 $Q_{\pi^*}(s, a)$ ，Q-learning 之名正由此而来；随后像式 6.18 那样，对这些 Q 值采取贪心行动，以得到 $\pi^*(s | a)$ 。

⁸由式 6.10，回报是期望 $V_\pi(s_t) = \mathbb{E}[G_t | s_t, \pi]$ 的无偏估计量。这称为样本更新（sample update），因为我们只用单个样本确定期望。

⁹Q-learning 是一种离策略（off-policy）算法，这意味着它学习的策略（最优策略 $\pi^*(a | s)$ ）不同于训练回合中遵循的策略。SARSA 等算法则是同策略（on-policy）算法，学习与生成训练数据的策略相对应的价值函数。

首先任意初始化所有 $s \in \mathcal{S}, a \in \mathcal{A}$ 的估计 $Q_\pi(s, a)$ ；这些估计通常存储在表中（使用神经网络的实现见节 6.2.3）。随后，按照策略采样轨迹 $\tau \sim p(\tau)$ ，并用下式逐步更新估计：

$$Q_\pi(s, a) = Q_\pi(s, a) + \eta \left(r + \gamma \max_{a'} Q_\pi(s', a') - Q_\pi(s, a) \right). \quad (6.22)$$

这一过程见算法 9.

算法 9 Q-learning

输入： 学习率 η ，最大时刻 T ，策略参数 ε

初始化 $Q(s, a) \forall s \in \mathcal{S}, a \in \mathcal{A}$

while 尚未收敛 **do**

 初始化 s_0

for $t = 0$ 到 $T - 1$ **do**

$\xi \leftarrow \text{uniform} \in [0, 1]$

$a \leftarrow$ 均匀采样的 a **若** $\xi \leq \varepsilon$, **否则** $\arg \max_a Q_\pi(s, a)$ ▷ ε -贪心策略

 移动至下一状态 s' 并获得奖励 r

$Q(s, a) \leftarrow Q(s, a) + \eta (r + \gamma \max_{a'} Q(s', a') - Q(s, a))$

end for

end while

返回 $Q(s, a)$ ▷ 所有状态与行动的最优行动价值函数

只要所有可能的状态-行动对持续得到更新，这一方法便保证收敛到最优行动价值函数。对所有收敛到最优行为的算法而言，这都是必要条件；对完全确定性策略，它可能成为问题。不过，在 Q-learning 中，可以采用 $\varepsilon \neq 0$ 的 ε -贪心策略，以确保满足这一条件。

关键在于，策略虽然决定智能体访问哪些状态和行动，但如式 6.22 所示，Q 值更新是在贪心的下一行动上进行的。这样，学得 Q 值对应于在其上采取贪心行动的策略，而该策略正是满足 Bellman 最优性方程式 6.16 的策略。

6.2.2 Double Q-learning

大多数时序差分算法都存在最大化偏差（maximization bias），它会导致 Q 值被高估，从而损害性能。在 Q-learning 中尤其如此，因为会遇到两次最大化：一次发生在 ε -贪心策略中，另一次发生在贪心目标策略中（式 6.22）。这样，我们用被高估值中的最大值（见下文）来更新最大 Q 值；后者对应于策略采取的贪心行动，因此可能给 $Q_\pi(s, a)$ 带来显著的正偏差。

式 6.22 中对下一步可能行动的最大化，是最大期望值 $\max_{a'} \mathbb{E}[Q_\pi(s', a')]$ 的样本估计。然而，它是一个正偏估计量（positively biased estimator），因为样本估计实际上对应于最大值的期望 $\mathbb{E}[\max_{a'} Q_\pi(s', a')]$ [384]。文献 [378] 给出了一个建立直觉的简单例子：假设某状态下所有行动的真实 Q 值都为零，而我们的估计 $Q_\pi(s, a)$ 围绕零分布，既取正值也取负值。最大值为正，因此构成高估。Q 值的高估可能阻止算法学得最优策略 [385]。

可以用Double Q-learning (double Q-learning) [386] 克服这一问题. 这里不再学习一组 Q 值, 而是学习两组: $Q_\pi^A(s, a)$ 和 $Q_\pi^B(s, a)$. 不过, 更新其中一组时, 要用另一组估计相应下一贪心行动的价值:

$$Q_\pi^A(s, a) = Q_\pi^A(s, a) - \eta \left(r + \gamma Q_\pi^B \left(s', \arg \max_{a'} Q_\pi^A(s', a') \right) - Q_\pi^A(s, a) \right). \quad (6.23)$$

其中 A, B 可以互换. 这一方法避免使用同一个估计量同时确定最大化行动及其价值, 从而得到无偏估计.

我们在每个时步随机选择一组进行更新, 以学习这两组价值. 与标准 Q-learning 相比, 唯一额外的区别是: 采取行动时遵循一个结合 $Q_\pi^A(s, a)$ 与 $Q_\pi^B(s, a)$ 信息的 ε -贪心策略, 例如使用二者之和或均值. Double Q-learning 以将内存需求加倍为代价, 克服了 Q-learning 的一个主要局限.

6.2.3 用神经网络实现 Q-learning

在节 6.2.1 所介绍的 Q-learning 中, 我们存储每一个可能状态-行动对的 Q 值 $Q_\pi(s, a)$. 这种方法使我们能够找到精确的最优行动价值函数. 然而, 它只适用于小型问题, 因为对于规模稍大的问题, 内存需求很快就会变得不可承受.

在这些情况下, 必须依靠一种高效方式表示所有 $s \in \mathcal{S}, a \in \mathcal{A}$ 上的 $Q_\pi(s, a)$. 神经网络是逼近行动价值函数的重要候选方案, 文献 [28] 首先引入了这种方法; 与状态-行动对的数量相比, 它所需的参数显著更少 (回顾节 2.4.4). 使用神经网络学习 Q 值称为深度 Q-learning (deep Q-learning), 相应网络通常称为深度 Q 网络 (deep Q-network, DQN). DQN 在输入层接收状态的表示 $\phi(s)$, 并在输出层设置与可能行动数相同的神经元数; 这些神经元编码所有 $a \in \mathcal{A}$ 的 $Q_\pi(s, a; \theta)$. 这里, θ 表示神经网络的可学习参数集合. 这样, 给定一个状态, DQN 便会给出所有可能行动的 Q 值.

不过, 如果直接应用算法 9 并采用如下网络参数更新规则, DQN 可能变得非常不稳定:

$$\theta = \theta + \eta \left(r + \gamma \max_{a'} Q_\pi(s', a'; \theta) - Q_\pi(s, a; \theta) \right) \nabla_\theta Q_\pi(s, a; \theta), \quad (6.24)$$

这类似于一个回归问题: 通过梯度下降, 使目标 $r + \gamma \max_{a'} Q_\pi(s', a'; \theta)$ 与预测 $Q_\pi(s, a; \theta)$ 之间的均方误差损失 (式 2.1) 最小化. 不稳定性主要来自轨迹上相邻观测之间的关联、目标与预测之间的关联, 以及参数微小变化导致的数据分布显著改变. 最后一种情形是因为智能体遵循 ε -贪心策略, 而参数的微小变化可能改变各状态下具有最大 Q 值的行动, 从而使轨迹进程突然改变.¹⁰ 我们通过经验回放 (experience replay) [387] 并引入目标网络 (target network) 来克服这些局限.

采用经验回放时, 智能体不再在每个时步学习, 而是把各回合中收集的经验存入内存, 其中保留每次转移 (s, a, r, s') 的信息. 随后, 一旦智能体积累了足够的经验, 它就从内存中随机采样一批转移进行回放, 以计算损失并更新 DQN 参数. 这样, 智能体便

¹⁰考虑两条分别通向不同宝藏的路径. 我们任意初始化 Q 值; ε -贪心策略主要沿 Q 值较高的路径前进, 同时以小概率 ε 偶尔沿另一条路径前进. 然而, 如果第二条路径通向更大的宝藏, 它的 Q 值最终会变得最高, 此时数据分布便会突然改变, 转而主要采样这条路径而偶尔采样另一条路径.

在收集经验的回合与通过经验回放进行学习之间交替. 这一技术消除了训练样本之间的关联, 并缓解了数据分布的突然变化. 此外, 它还使智能体能够复用经验, 以防止遗忘和重新学习.¹¹

为了消除目标与预测之间的关联, 我们考虑一个目标网络; 它是 DQN 的副本, 但以不同速率更新. DQN 参数 θ 在每次迭代中更新, 而目标网络参数 θ^- 仅每隔若干次迭代通过复制 θ 更新一次. 随后, 我们用它预测目标项 $\max_{a'} Q_\pi(s', a'; \theta^-)$, 目标网络之名正源于此. 这确保预测 $Q_\pi(s, a; \theta)$ 与目标不相关.

此外, 还可以更进一步, 将目标网络用于 Double Q-learning (见节 6.2.2), 以防止 DQN 高估行动价值函数; 这一方法由文献 [388] 引入. 因此, 整个实现过程包括: 遵循以 Q 值 $Q_\pi(s, a; \theta)$ 为依据的 ε -贪心策略来收集经验; 然后, 智能体回放从经验中随机选择的转移, 计算目标与预测之间的均方误差损失函数, 同时使用目标网络执行 Double Q-learning:

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \left(r_i + \gamma Q_\pi \left(s'_i, \arg \max_{a'} Q_\pi(s'_i, a'; \theta^-); \theta^- \right) - Q_\pi(s_i, a_i; \theta) \right)^2, \quad (6.25)$$

其中, i 表示从内存中随机采样的 n 个转移所组成批次中的索引. 随后, 我们对式 6.25 中的损失执行一步梯度下降, 以更新 θ . 最后, 每隔若干次迭代更新目标网络: $\theta^- \leftarrow \theta$.

6.3 策略梯度方法

强化学习的主要目标, 是找到使给定任务的期望回报最大化的最优策略 $\pi^*(a | s)$. 在策略梯度 (policy gradient) 算法中, 我们提出参数化 Ansatz $\pi_\theta(a | s)$ 并优化其参数 θ , 试图直接找到最优策略; 这与章 5 中的变分波函数类似. 因此, 寻找最优策略 $\pi^*(a | s)$ 等价于寻找能给出最佳逼近 $\pi_{\theta^*}(a | s) \approx \pi^*(a | s)$ 的最优参数集合 θ^* . 这种参数化可以采取多种形式, 例如神经网络; 控制策略的形状可能使我们能够利用有关任务的先验知识, 从而获得更好的结果. 此外, 这些策略是随机的, 天然具有探索性质, 同时又足够灵活, 也能逼近确定性策略.

为了优化参数, 我们使用一个要最大化的目标函数 O_π . 它可以是任意性能指标, 例如状态价值函数 V_π 、行动价值函数 Q_π 或回报 G . 对于连续的参数化策略, 目标函数随参数变化而平滑改变, 因此可以计算其导数. 我们采用梯度上升 (gradient ascent) 方法进行优化: 计算期望值的梯度 $\nabla_{\theta} \mathbb{E}[O_\pi | \pi_\theta]$, 并对参数 θ 作一次小更新. 期望值是对依据策略采样的轨迹 τ 取的 (回顾式 6.9).

直接计算梯度并不简单, 因为它依赖状态的平稳分布, 而在无模型强化学习中我们无法获得这一分布. 因此, 很难估计策略更新对状态分布的影响. 然而, 策略梯度定理 (policy gradient theorem) [389, 390] 给出了目标函数梯度的一种解析形式, 其中不含对状态分布的导数.

¹¹当获取经验的代价很高时, 这一点尤其有价值. 例如, 如果机器人受到严重损伤, 内存使它不必再次受伤, 也能继续从这一情形中学习.

策略梯度定理：对于任意可微策略 $\pi_{\theta}(a | s)$ 和目标函数 O_{π} ，其期望值的梯度 $\nabla_{\theta} \mathbb{E}[O_{\pi} | \pi_{\theta}]$ 可以表示为仅作用于对数策略 $\nabla_{\theta} \log \pi_{\theta}(a | s)$ 的导数。项 $\nabla_{\theta} \log \pi_{\theta}(a | s)$ 通常称为得分函数（score function）。

为了进一步理解上述定理，考虑以总回报 $G(\tau)$ 为目标函数的例子（使用 $V_{\pi}(s)$ 的扩展证明见文献 [378]）。因此，我们希望使期望值 $\mathbb{E}[G | \pi_{\theta}]$ 最大化；该期望是在轨迹 $\tau \sim p_{\theta}(\tau)$ 上取的。我们重述式 6.9，以明确显示其参数依赖：

$$p_{\theta}(\tau) = \prod_{t=0}^{T-1} p(s_{t+1} | s_t, a_t) \pi_{\theta}(a_t | s_t). \quad (6.26)$$

因此，可以把期望写成

$$\mathbb{E}[G | \pi_{\theta}] = \sum_{\tau} p_{\theta}(\tau) G(\tau). \quad (6.27)$$

为了取梯度，先回顾对数导数的性质 $\nabla_{\theta} p_{\theta} = p_{\theta} \nabla_{\theta} \log p_{\theta}$ ，并将其用于以下推导：

$$\begin{aligned} \nabla_{\theta} \mathbb{E}[G | \pi_{\theta}] &= \sum_{\tau} G(\tau) \nabla_{\theta} p_{\theta}(\tau) \\ &= \sum_{\tau} G(\tau) p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau). \end{aligned} \quad (6.28)$$

随后，由式 6.26 可见， $p_{\theta}(\tau)$ 对 θ 的唯一依赖来自策略。因此，

$$\nabla_{\theta} \log p_{\theta}(\tau) = \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t), \quad (6.29)$$

将其与式 6.28 结合，得到

$$\begin{aligned} \nabla_{\theta} \mathbb{E}[G | \pi_{\theta}] &= \sum_{\tau} p_{\theta}(\tau) G(\tau) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \\ &= \mathbb{E} \left[G(\tau) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \middle| \pi_{\theta} \right] \end{aligned} \quad (6.30)$$

策略梯度定理的重要性在于，它以期望值形式给出了梯度的闭式表达。因此，我们可以通过对不同轨迹 τ 作 Monte Carlo 采样来估计它。此外，目标函数的梯度与初始状态 s_0 无关，因为它不依赖策略。

6.3.1 REINFORCE

REINFORCE 算法 [391] 是最常用的策略梯度算法之一，它以回报作为目标，即 $O_{\pi} = G(\tau)$ 。¹²

¹²在节 6.1.5 中，我们提到最优策略使所有 $s \in \mathcal{S}$ 上的 $V_{\pi}(s)$ 最大化。以 $V_{\pi}(s)$ 为目标时，梯度为 $\nabla_{\theta} \mathbb{E}[V_{\pi}(s) | \pi_{\theta}] = \mathbb{E}[Q_{\pi}(s, a) \nabla_{\theta} \log \pi_{\theta}(a | s) | \pi_{\theta}]$ （见文献 [378]）。在 REINFORCE 中， G_t 是 $Q_{\pi}(a_t, s_t)$ 的无偏估计量，可用于寻找最优策略，因为根据式 6.11， $Q_{\pi}(a_t, s_t) = \mathbb{E}[G_t | s_t, a_t, \pi_{\theta}]$ 。

REINFORCE 的主要原理，是直接修改策略，使智能体经验中那些带来高回报的行动序列更受偏好。这样，智能体下一次与环境交互时，先前有益的行动就更可能发生。

形式上，我们求解优化问题 $\theta^* = \arg \max_{\theta} \mathbb{E}[G \mid \pi_{\theta}]$ 。我们通过迭代更新规则寻找 θ^* ：计算梯度 $\nabla_{\theta} \mathbb{E}[G \mid \pi_{\theta}]$ ，并沿其方向执行一步梯度上升。实际上，我们采样一批 n 条轨迹 $\tau \sim p_{\theta}(\tau)$ （也称为回合），以近似式 6.30 中的期望值。因此，在学习迭代 k 时，

$$\Delta \theta_k \approx \frac{1}{n} \sum_{i=1}^n G(\tau_i) \sum_{t=0}^{T_i-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t), \quad (6.31)$$

$$\theta_{k+1} = \theta_k + \eta \nabla \theta_k, \quad (6.32)$$

其中 η 是学习率。¹³ 这一过程见算法 10。

算法 10 REINFORCE

输入：学习率 η ，轨迹数 n ，最大时间 T

输入：随机初始化的可微策略 $\pi_{\theta}(a \mid s)$

while 未收敛 **do**

for $i = 1$ 到 n **do**

 初始化 s_0

for $t = 0$ 到 $T - 1$ **do**

 采取行动 $a_t \sim \pi_{\theta}(a_t \mid s_t)$ ，并存储 $\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t)$

 转移到下一状态 s_{t+1} ，并存储奖励 r_{t+1}

end for

$G^{(i)} \leftarrow \sum_t \gamma^t r_{t+1}$

$z^{(i)} \leftarrow \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t)$

end for

$\Delta \theta \leftarrow (1/n) \sum_i G^{(i)} z^{(i)}$

$\theta \leftarrow \theta + \eta \Delta \theta$

end while 返回 θ

▷ 最优策略参数

然而，轨迹采样会给期望量引入显著涨落，造成很大的训练方差；这是所有基于 Monte Carlo 的方法都面临的一般问题。有些回合可能相当成功，另一些则可能彻底失败，回报极低。如此高的方差会造成不稳定的策略更新，增加向最优策略收敛所需的时间。处理这一问题的一种常用技术，是在回报中引入基线（baseline）；它能够在不引入任何偏差的情况下减小方法的方差，因此应当始终使用。

为了更好地说明基线，先把式 6.30 改写成更方便的形式；本章以下部分省略条件

¹³在某些情况下，把梯度的期望计算为以轨迹回报加权的和会有所帮助。此时，不除以 n ，而除以 $\sum_{\tau} G(\tau)$ ，从而使更新规则与回报的尺度无关。这种方法忽略回报为零的轨迹；这些轨迹不贡献梯度，却会稀释信息，导致更新非常小。

$\mathbb{E}[\cdot \mid \pi_\theta]$:

$$\begin{aligned}
\nabla_\theta \mathbb{E}[G \mid \pi_\theta] &= \mathbb{E} \left[\left(\sum_{t'=0}^{T-1} \gamma^{t'} r_{t'+1} \right) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right] \\
&= \mathbb{E} \left[\sum_{t'=0}^{T-1} \gamma^{t'} r_{t'+1} \sum_{t=0}^{t'} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right] \\
&= \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \sum_{t'=t}^{T-1} \gamma^{t'} r_{t'+1} \right] \\
&= \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t G_t \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{6.33}
\end{aligned}$$

第一行写出了 $G(\tau)$ 的显式形式. 第二行使用了关系

$$\begin{aligned}
\nabla_\theta \mathbb{E}[G \mid \pi_\theta] &= \nabla_\theta \mathbb{E} \left[\sum_{t'=0}^{T-1} \gamma^{t'} r_{t'+1} \right] = \sum_{t'=0}^{T-1} \nabla_\theta \mathbb{E}_{\tau_{t'}} [\gamma^{t'} r_{t'+1}] \\
&= \sum_{t'=0}^{T-1} \mathbb{E}_{\tau_{t'}} \left[\gamma^{t'} r_{t'+1} \sum_{t=0}^{t'} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right] \\
&= \mathbb{E} \left[\sum_{t'=0}^{T-1} \gamma^{t'} r_{t'+1} \sum_{t=0}^{t'} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{6.34}
\end{aligned}$$

这里, $\mathbb{E}_{\tau_{t'}}$ 表示对直至时刻 t' 的轨迹取期望. 随后, 在式 6.33 第三行中, 我们重排求和项, 找到带有偏移因子 γ^t 的 G_t 显式形式. 最后一式更清楚地表明, 轨迹中过去的奖励不会对给定时刻之后的策略梯度作出贡献, 从而恢复 Markov 性.

在式 6.33 中引入依赖状态的基线 $b(s_t)$, 可以减小梯度方差, 使得

$$\nabla_\theta \mathbb{E}[G \mid \pi_\theta] = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t (G_t - b(s_t)) \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{6.35}$$

只要基线不依赖行动, 任何基线都适用. 这样不会引入偏差, 因为

$$\begin{aligned}
\mathbb{E}[b(s_t) \nabla_\theta \log \pi_\theta(a_t \mid s_t)] &= \mathbb{E}_{\tau_t} [b(s_t) \mathbb{E}_{\tau_{t:T}} [\nabla_\theta \log \pi_\theta(a_t \mid s_t)]] \\
&= \mathbb{E}_{\tau_t} \left[b(s_t) \sum_{a_t} \pi_\theta(a_t \mid s_t) \nabla_\theta \log \pi_\theta(a_t \mid s_t) \underbrace{\sum_{s_{t+1}} p(s_{t+1} \mid s_t, a_t)}_1 \underbrace{\sum_{\tau_{t+1:T}} p_\theta(\tau_{t+1:T})}_1 \right] \\
&= \mathbb{E}_{\tau_t} \left[b(s_t) \nabla_\theta \underbrace{\sum_{a_t} \pi_\theta(a_t \mid s_t)}_1 \right] = \mathbb{E}_{\tau_t} [b(s_t) \cdot 0] = 0. \tag{6.36}
\end{aligned}$$

这里, $\tau_{t:T}$ 表示从时刻 t 到终止时刻 T 的轨迹. 从第二行到第三行时, 我们使用了与式 6.28 相同的对数导数性质. 注意, 即使基线依赖 θ , 期望仍保持无偏.

虽然期望不受影响，基线却可能显著影响方差。¹⁴ 考虑与状态无关的基线。我们可以对每个参数找到使梯度方差最小的最优基线。为简化记号，令 z_k 和 b_k 分别为得分函数 $z_k = \partial_{\theta_k} \log \pi_{\theta}(a | s)$ 与一个状态无关的基线向量的第 k 个分量。因此，目标是使式 6.35 被积项中的 $(G_t - b_k)z_k$ 的方差最小，¹⁵ 即寻找 $b_k^* = \arg \min_{b_k} \text{Var}[(G_t - b_k)z_k]$ ，使 $\partial_{b_k^*} \text{Var}[(G_t - b_k)z_k] = 0$ 。因而，

$$\text{Var}[(G_t - b_k)z_k] = \mathbb{E}[(G_t - b_k)z_k]^2 - \mathbb{E}[G_t z_k]^2, \quad (6.37)$$

$$\partial_{b_k} \text{Var}[(G_t - b_k)z_k] = -2\mathbb{E}[(G_t - b_k)z_k^2], \quad (6.38)$$

$$b_k^* = \frac{\mathbb{E}[G_t z_k^2]}{\mathbb{E}[z_k^2]}. \quad (6.39)$$

第一式使用式 6.36 从第二项中消去了 b_k 。

除上述与状态无关的例子外，还可以考虑其他几种有效基线，它们可能带来更好的结果。例如，价值函数估计 $\hat{V}_{\pi}(s_t) \approx \mathbb{E}[G_t | s_t]$ 是一种常见的状态依赖基线。它既可以直接从 G_t 学得，也可以像节 6.4 所示那样学习，还可以在自评论家方案中通过采样估计（见文献 [392]）。使用这种基线时，在当前策略下产生高于期望回报的行动会得到强化，而产生较低奖励的行动会受到惩罚。这等价于用优势对得分函数加权。根据式 6.11， $\mathbb{E}[G_t | s_t, a_t] = \mathbb{E}[Q_{\pi}(s_t, a_t) | s_t, a_t]$ ；减去基线 $b(s_t) = V_{\pi}(s_t)$ ，便得到优势的期望（回顾式 6.12）。因此， $\nabla_{\theta} \mathbb{E}[G | \pi_{\theta}] = \mathbb{E}[\sum_t \gamma^t A(s_t, a_t) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)]$ 。直接估计优势给出尽可能小的方差；进一步讨论见文献 [393]。

另一种常见做法是对回报作白化（whiten）。这指减去一条轨迹所有时步上的回报均值，再除以其标准差，即 $\bar{G}_t = (G_t - \langle G \rangle) / \sigma_G$ 。由于这并不严格属于基线，该方法确实会引入偏差。

6.3.2 用神经网络实现 REINFORCE

参数化策略 π_{θ} 是策略梯度方法中的核心量；只要它关于参数可微，就可以采取任意形式。在离散行动空间中，最常用的方法之一是按照 softmax 分布定义行动概率：

$$\pi_{\theta}(a | s) = \frac{e^{x(s,a)}}{\sum_{a' \in \mathcal{A}} e^{x(s,a')}}. \quad (6.40)$$

其中， $x(s, a)$ 是状态 s 下行动 a 的行动偏好（action preference）。

定义行动偏好的最简单方式，是把一组线性参数 θ 作用于状态与行动的特征表示 $\phi(s, a)$ ，使 $x(s, a) = \theta^{\top} \phi(s, a)$ 。然而，在复杂问题中，这种方法可能缺乏逼近最优策略 π^* 所需的表达能力。

在这些情况下，可能需要用深度神经网络参数化行动偏好。神经网络是线性参数方法的自然推广；例如，可以增加隐藏层的数量或规模，以调节并提高表达能力。这样，参数化策略的神经网络在输入层接收状态表示 $\phi(s)$ ，并在输出层设置与可能行动数相同的

¹⁴回顾 $\text{Var}[x] = \mathbb{E}[x^2] - \mathbb{E}[x]^2$ 。因此，加入期望为零的项不会影响第二项，却会影响第一项： $\text{Var}[x - b] = \mathbb{E}[(x - b)^2] - \mathbb{E}[x - b]^2 = \mathbb{E}[(x - b)^2] - \mathbb{E}[x]^2$ 。

¹⁵这里采用近似 $\text{Var}[\sum_t X_t] \approx \sum_t \text{Var}[X_t]$ 。

神经元数，以编码所有 $a \in \mathcal{A}$ 的 $x(s, a)$. 在输出层应用 softmax 激活函数（见式 2.37），便得到与式 6.40 相同的所有 $a \in \mathcal{A}$ 上的 $\pi_\theta(a | s)$.

训练过程类似于在智能体收集的经验上训练监督分类器. 使用式 6.35 中的梯度实现 REINFORCE，等价于以修改后的类别交叉熵损失（回顾式 2.3）执行梯度下降：

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \sum_{t=0}^{T-1} \gamma^t (G_{ti} - b(s_{ti})) \log \pi_\theta(a_{ti} | s_{ti}). \quad (6.41)$$

其中， i 表示由 n 条轨迹组成的批次中的索引. 这样，该过程类似于训练一个以行动作为状态标签的神经网络分类器. 与监督分类问题的主要区别在于：给定状态后，我们不知道行动的真实概率分布（真实标签），因为它应由最优策略给出. 相反，我们把所得回报 G_t 指派为所采取行动 a_t 的真实标签.¹⁶ 直观而言，在分类问题中，我们希望提高神经网络给出正确标签的概率；而这里，我们强化具有高回报的行动.

在许多情形中，行动可以在一定连续数值范围内取值，而不是来自离散类别集合. 例如，机器人手臂可以转过某个角度，实验装置中的多个连续参数也可以调节. 有时，我们可以把行动空间离散成小区间，但代价是精度损失和行动数量增加. 不过，这未必总能满足问题要求，而且所得行动数也可能使离散化不可行.

在这些情况下，我们用均值 μ 和标准差 σ 对随机连续行动建模，使得

$$a = \mu + \sigma \xi, \quad (6.42)$$

其中， ξ 是方差为一的正态随机变量. 与上述行动偏好类似，可以用多种方式参数化 $\mu_\theta(s)$ 和 $\sigma_\theta(s)$ ：从一组线性参数，例如 $\mu_\theta(s) = \theta^\top \phi(s)$ ，到一个具有两个输出神经元的神经网络；这两个神经元针对给定观测分别确定 $\mu_\theta(s)$ 和 $\sigma_\theta(s)$. 形式上，

$$\pi_\theta(a | s) = \frac{1}{\sigma_\theta(s) \sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{a - \mu_\theta(s)}{\sigma_\theta(s)} \right)^2 \right]. \quad (6.43)$$

在许多情况下，随着学习推进，智能体越来越善于采取正确行动，即选择 $\mu_\theta(s)$ ，偏差会逐渐减小，最终得到一种准确定性策略.

6.4 演员-评论家方法

在节 6.2 中，我们介绍了基于价值的强化学习，其中包括节 6.2.1 中的 Q-learning 算法. 这些方法善于处理离散状态-行动空间；其时序差分性质使它们具有较高的数据效率，并能处理持续任务（continuing task）（无限回合）. 然而，它们难以处理大型状态-行动空间，也无法处理其连续版本. 此外，它们只能实现确定性贪心策略，而许多问题具有随机最优策略. 最后，价值函数的微小变化可能引起策略的大幅变化，从而造成学习不稳定.

¹⁶ 标准类别交叉熵为 $\mathcal{L} = -\frac{1}{n} \sum_n \sum_k p(a_k) \log \pi_\theta(a_k | s)$ ，其中 $p(a_k)$ 是我们希望学习的真实概率分布. 在标准分类问题中，它对真实标签通常为 1，对其余标签为 0. 这里，它对应最优策略 $p(a_k) = \pi^*(a_k | s)$. 由于我们无法访问 π^* （它正是我们的目标！），便用所选行动的回报 G_t 代替它，因为 π^* 会偏好高回报行动. 这实际上消去了对行动的期望，并在式 6.41 中显式写出对时间的求和.

另一方面，我们在节 6.3 中介绍了策略梯度方法，其中包括节 6.3.1 中的 REINFORCE 算法。这些算法克服了上述基于价值方法的局限，因为它们能够处理连续（无限）状态-行动空间，并且基于连续随机策略，可保证策略在学习过程中平滑变化，且在需要时能够变成确定性策略。不过，学习要等到回合结束、回报已知后才会发生；这对长轨迹或持续任务而言是一个问题。

演员-评论家 (actor-critic) 算法结合基于价值与基于策略的方法，以兼取二者之长。可以把演员-评论家方法理解为策略梯度的时序差分版本；它保留了策略梯度的全部优点，同时克服其主要局限。这种方法包含两个主要元素：演员 (actor)，即支配决策的参数化策略；以及评论家 (critic)，即评价这些决策的模型。

评论家的存在使智能体无需等待回合结束时的结果，就能立即从每个行动中学习。评价策略主要包括学习其价值函数，从而使评论家能够评估行动更有利还是更不利。在节 6.3.1 中，我们引入状态价值函数 $V_\pi(s)$ ，作为减小策略梯度方差的最优基线。不过，在这种情况下，我们只考察转移中初始状态的 $V_\pi(s)$ ，因而无法评价行动。¹⁷

然而，我们已经说明，使用这种基线可以根据式 6.12 引入的优势 $A(s, a)$ 来计算梯度。优势的显式形式奠定了演员-评论家方法的基础 [394, 395, 396]：

$$A(s_t, a_t) = \mathbb{E}[r_{t+1} + \gamma V_\pi(s_{t+1}) - V_\pi(s_t)]. \quad (6.44)$$

它由式 6.12 和式 6.14 导出。这一表达式位于时序差分算法的核心，因为它对应于式 6.20 中的时序差分误差。

在式 6.44 中，我们用 $V_\pi(s)$ 评价给定转移的初始状态和最终状态，从而构成行动的评论家。这使智能体能够在 REINFORCE 的每个时步学习，像节 6.2 中的时序差分算法一样，在状态、行动和奖励出现时就处理它们。不过，这一优势的代价是要学习两个模型：策略 $\pi_\theta(a | s)$ 与状态价值函数 $V_\pi(s; \mathbf{w})$ ；二者通常分别由参数为 θ 和 $\mathbf{w}$ 的神经网络参数化。参数化状态价值函数的神经网络在输入层接收状态的特征表示 $\phi(s)$ ，并用单个输出神经元编码 $V_\pi(s; \mathbf{w})$ 。策略的参数化方式与节 6.3.2 相同。我们按照算法 11 同时训练两个模型。

¹⁷为了确定行动的质量，需要比较初始位置与最终位置。在游戏中，一个使局面从濒临失败转到不那么不利位置的行动，可能比一个使本已占优的局面略有改善的行动更有价值，尽管后者给出的最终状态价值函数更高。

算法 11 演员–评论家

输入： 学习率 η_θ, η_w ，最大时间 T

输入： 随机初始化的可微策略 $\pi_\theta(s | a)$

输入： 随机初始化的可微状态价值函数 $V_\pi(s; \mathbf{w})$

while 未收敛 do

 初始化 s_0

 for $t = 0$ 到 $T - 1$ do

 采取行动 $a \sim \pi_\theta(a | s)$

 转移到下一状态 s' 并获得奖励 r

$A \leftarrow r + \gamma V_\pi(s'; \mathbf{w}) - V_\pi(s; \mathbf{w})$

$\theta \leftarrow \theta + \eta_\theta \gamma^t A \nabla_\theta \log \pi_\theta(a | s)$

▷ 更新演员

$\mathbf{w} \leftarrow \mathbf{w} + \eta_w A \nabla_w V(s; \mathbf{w})$

▷ 更新评论家

 end for

end while 返回 $\theta, \mathbf{w}$

▷ 最优演员与评论家参数

我们使用节 6.3 中的方法训练演员，并依据节 6.2 中的原理训练评论家。因此，这两节中的全部方法都适用于该算法。算法 11 中的参数更新来自：对演员使用式 6.35 执行梯度上升；对评论家采用与式 6.22 类似的更新规则，只是用 $V_\pi(s)$ 代替 $Q_\pi(s, a)$ 。这一过程分别等价于对损失 $\mathcal{L}_\theta = \frac{1}{n} \sum_n \sum_t \gamma^t A(s_t, a_t; \mathbf{w}) \log \pi_\theta(a_t | s_t)$ 和 $\mathcal{L}_w = \frac{1}{n} \sum_n A(s, a; \mathbf{w})^2$ 执行梯度下降；这里省略了对 n 个样本求和时的索引。它们与式 6.41 和式 6.25 基于相同原理。

这种方法通常称为优势演员–评论家 (advantage actor–critic, A2C)。进一步引入异步演员后，得到异步优势演员–评论家 (asynchronous advantage actor–critic, A3C) 算法 [397]。其他改进依赖更高级的优化技术，例如自然梯度 (natural gradient) [398]，以及使用它的自然策略梯度 [399]、自然演员–评论家 [400, 401]，或更复杂的参数更新，例如信赖域 (trust region) 方法 [402, 403] 和近端策略优化 (proximal policy optimization) 算法 [404]。

6.5 投影模拟

近年来，人们提出了一些新的强化学习方法，它们探索了超越节 6.2 和节 6.3 中所介绍的原型基于价值方法与策略梯度方法的技术。其中，投影模拟 (projective simulation, PS) [405] 因在物理学中有众多应用，而对物理学界尤具吸引力。

投影模拟考虑基于情节与组合记忆 (episodic and compositional memory, ECM) 的智能体。ECM 是一种数学对象，能够存储已访问状态和已采取行动的信息，并在它们之间建立联系。因此，随着智能体积累经验，ECM 会持续更新，并最终决定任意给定状态下的策略，如下所示。ECM 通常表示为图 6.3(a) 所示的有向加权图。节点在此定义为片段 (clip)，表示智能体已访问的状态、已采取的行动或所学到的隐藏信息。随着智能体探索，与新访问状态对应的片段会加入图中。类似地，智能体也可以创建额外片段，以容纳新行动（例如两个行动的组合）或隐藏信息。边带有权重，每个新节点的边权初始化为均匀值。权重决定片段之间的转移概率，并会随着智能体获得奖励而更新。




图 6.3: 不同投影模拟智能体的情节与组合记忆示意图. (a) 一个多层 ECM, 含 m 个状态节点 (粉色)、3 个隐藏节点 (红色) 和 m 个行动节点 (黄色). 图的连接性也可设置为三层 ECM. (b) 一个用于展示 PS 模型特征提取能力的三层 ECM. 详见正文.

如前所述, ECM 定义 PS 智能体的策略. 在原始 PS 中, 给定一个观测状态, 智能体从对应的状态片段出发, 在 ECM 上执行加权随机游走 (weighted random walk). 游走一旦到达行动节点就结束, 并选择相应行动. 从片段 c_i 跳转到另一片段 c_j 的概率, 可以是边权 $h(c_i, c_j)$ 的任意归一化函数, 例如

$$P(c_i, c_j) = \frac{h(c_i, c_j)}{\sum_{j \in \mathcal{I}} h(c_i, c_j)}. \quad (6.45)$$

其中, $\mathcal{I}$ 是 c_i 的边集. 人们还提出了其他转移函数, 例如 softmax 转移, 它允许 h 取任意值.

按照上述方案, 训练 PS 智能体包括通过加入新节点来更新 ECM, 并学习边权. 目标是使每个状态片段在 ECM 中的路径都以高概率通向正确行动. 因此, 训练可归约为在每个时步按下式更新 h 值:

$$h(c_i, c_j) \leftarrow h(c_i, c_j) + \gamma(h(c_i, c_j) - 1) + r. \quad (6.46)$$

其中, c_i 和 c_j 表示在 ECM 随机游走中经过的片段, γ 是阻尼参数, r 是执行所选行动后环境给出的奖励.

在这一更新规则下, 智能体每作出一次决策, 即每次从状态节点游走到行动节点时, 所有已访问边的 h 值都会更新. 这样, 游走路径上的 h 值总会以因子 γ 阻尼; 若它们导致了有奖励的行动, 其值还会增加 r .

在许多实际场景中, 奖励是在一长串行动结束时才获得的, 例如在网格世界中走过多步以到达目标. 因此, 将这种奖励“反向传播”到导致它的整个行动序列十分重要. 例如, 在时序差分算法中, 如节 6.2 所介绍, 这是通过在更新时考虑未来状态的期望价值实现的. 为具备这种性质, 可以引入边辉光 (edge glow) 的概念, 对式 6.46 的更新规则进行推广: 每当一条边被经过, 它就开始发光, 并随时间衰减. 这一特性使智能体能够更新 ECM 中参与了产生某一奖励的轨迹 $\tau = a_0, s_1, a_1, \dots$ 所需决策的全部边.¹⁸ 此时更

¹⁸注意不要混淆 ECM 中的轨迹与状态-行动空间中的轨迹. 给定状态 s_t , PS 智能体通过在 ECM 中执

新规则可重写为

$$h(c_i, c_j) \leftarrow h(c_i, c_j) - \gamma(h(c_i, c_j) - 1) + g(c_i, c_j)r, \quad (6.47)$$

其中, g 是辉光值.

每当某条边被访问, 就将其对应的辉光值设为 1. 随后在每一步, 所有辉光值都按下式阻尼:

$$g(c_i, c_j) \leftarrow g(c_i, c_j)(1 - \eta). \quad (6.48)$$

这会以速率 η 有效降低所有辉光值. 这意味着, 最近被访问且导致奖励 $r \neq 0$ 的边会得到强化, 而较早访问的边得到的更新较小, 这与时序差分算法类似. 关于 PS 模型用法的深入实用说明, 参见文献 [406, 407].

上述 PS 方法与节 6.2.1 中的 Q-learning 类似, 是一种表格型方法 (tabular method), 因为智能体的审议过程保存在 ECM 的邻接矩阵, 即 h 矩阵中. 如前所述, 在处理大型行动空间和状态空间时, 表格型方法存在严重局限. 人们已经提出非表格型 PS 方法 [408]. 在这种情况下, 训练一个神经网络 (更准确地说, 一个基于能量的模型), 使其输出某个状态-行动对的 h 值; 这与节 6.2.3 中介绍的用深度 Q 网络预测 Q 值类似.

PS 模型的一项重要特性是它的透明性和潜在的可解释性, 这与 Q-learning 等其他方法形成对比. 在后者中, Q 值编码一个行动-状态元组所获得的期望奖励. 由于策略依赖于执行 Q 值最大的行动, 除这一最大化操作外, 几乎没有可解释空间. 相反, PS 构造一个可见图, 编码节点之间的跳转概率. 这些节点既可以表示强化学习任务中的直接信息, 即行动和状态, 也可以表示智能体提取的隐藏信息. 例如, 如节 6.6.6 所述, 文献 [375] 的作者能够解释 ECM 的隐藏结构; 在该例中, 此结构与不同光学器件有关. 有趣的是, PS 智能体能够把多个行动组合成新的联合节点, 从而创建由多个器件构成的有用光学装置 (见文献 [405]). 不过, 在所谓两层 PS (一层状态节点和一层行动节点) 中, PS 归约为与 Q-learning 非常相似的模型. 确实, 近期工作已对两种方法进行了广泛比较 [409]. 然而, 我们还可引入更多隐藏节点, 构建图 6.3(a) 所示的更深 PS 模型.

人们已经多次尝试构建这种深层 PS 架构, 并证明它们确实能从环境或当前任务中提取相关的隐藏特征 [410, 411]. 文献 [411] 给出了一个很有启发性的例子, 我们在图 6.3(b) 中对其作了示意性复现. 该工作给智能体提供一组具有不同物理性质 (如质量、电荷和体积) 的物体. 为简单起见, 这些量只能取 0、1 或 2 三个值之一. 智能体可以进行不同实验, 每个实验分别测量这些量之一. 状态因而是具有某些性质的不同物体; 例如, 在图 6.3(b) 中, S_2 是质量为 0、体积为 2 的物体, 这些值显然采用任意单位或类别. 另一方面, 行动是对各种实验结果的预测. 例如, a_1 表示预测该物体在实验一 (在此与质量有关) 中的测量值最低, a_2 表示同一实验的中间值, 依此类推. 作者证明, PS 智能体会把隐藏节点指派给问题中有意义的特征. 具体而言, 每个隐藏节点都会表示某一物理量的一个特定值, 如图 6.3(b) 所示. 这一有趣特性不仅是 PS 模型可解释性的有价值征兆, 而且已被证明能提高其泛化性能.

行一条从对应 s_t 节点出发、直到到达行动节点的轨迹, 选择行动 a_t . 然后执行相应行动 a_t , 转移到下一状态 s_{t+1} .

6.6 示例与应用

本节展示一系列具有代表性的强化学习应用. 在所有这些示例中, 可以找到前几节讨论的各种强化学习范式的实例. 我们先从两个玩具示例出发; 它们具有解析解, 因而可用来奠定策略梯度的理论基础. 随后, 我们简要评述若干最著名的强化学习实例: Atari 视频游戏和围棋. 最后, 我们强调强化学习在量子物理中的若干应用, 更准确地说, 是在量子电路、量子纠错和量子认证等未来量子技术的语境下.

6.6.1 玩具示例

下面通过求解两个玩具示例, 说明节 6.3.1 中的 REINFORCE 算法. 这些简单情形使我们能够解析求解所有方程, 从而奠定理论基础并熟悉基本概念.

考虑一个可在一维路径上移动的智能体, 它只有两个行动: 向上或向下移动. 智能体每向上移动一次, 就获得正奖励 $r_t = +1$; 每向下移动一次, 就获得负奖励 $r_t = -1$. 考虑无折扣情形 $\gamma = 1$, 一条 T 步轨迹的回报就是最终位置 $G(\tau) = x_T$. 也可用智能体向上或向下行动的次数表示它: $G(\tau) = n_{\text{up}} - n_{\text{down}} = 2n_{\text{up}} - T$. 显然, 无论当前位置如何, 最优策略都是始终向上移动.

在这种简单情形中, 智能体没有状态概念, 因此策略只依赖行动. 此外, 由于只有两个可能行动, 我们可以为其中一个定义参数化策略, 例如 $\pi_{\theta}(\text{up}) \in [0, 1]$, 并取另一个为 $\pi_{\theta}(\text{down}) = 1 - \pi_{\theta}(\text{up})$. 考虑参数化 sigmoid 策略

$$\pi_{\theta}(\text{up}) = \frac{1}{1 + e^{-\theta}}, \quad \pi_{\theta}(\text{down}) = \frac{1}{1 + e^{\theta}}. \quad (6.49)$$

它们分别通过单个参数 θ 决定向上或向下移动的概率. 它们的得分函数为

$$\nabla_{\theta} \log \pi_{\theta}(\text{up}) = \pi_{\theta}(\text{down}), \quad \nabla_{\theta} \log \pi_{\theta}(\text{down}) = -\pi_{\theta}(\text{up}). \quad (6.50)$$

利用式 6.49 和式 6.50, 可以解析计算式 6.31 中的参数更新规则. 可将其各项表示为 $\pi_{\theta}(\text{up})$ 的函数:

$$\begin{aligned} & \mathbb{E} \left[G(\tau) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t) \right] \\ &= \mathbb{E} [(n_{\text{up}} - n_{\text{down}}) (n_{\text{up}} \pi_{\theta}(\text{down}) - n_{\text{down}} \pi_{\theta}(\text{up}))] \\ &= \mathbb{E} [(2n_{\text{up}} - T) (n_{\text{up}} - T \pi_{\theta}(\text{up}))] \\ &= 2 \mathbb{E} \left[(n_{\text{up}} - T/2) (n_{\text{up}} - \langle n_{\text{up}} \rangle_{\pi_{\theta}}) \right] \\ &= 2 \text{Var} [n_{\text{up}}] = 2T \pi_{\theta}(\text{up}) (1 - \pi_{\theta}(\text{up})). \end{aligned} \quad (6.51)$$

这里, 我们把 $T \pi_{\theta}(\text{up})$ 取为向上移动次数的期望 $\langle n_{\text{up}} \rangle_{\pi_{\theta}}$. 由此, 我们能够在这个简单情形中得到参数更新规则的封闭解析形式, 而这在强化学习中并不常见. 这使我们能够理解行动是如何得到强化的. 例如, 项 $n_{\text{up}} - \langle n_{\text{up}} \rangle_{\pi_{\theta}}$ 会强化那些使向上移动次数高于策略期望的行动, 并惩罚那些导致较少向上移动的行动.




图 6.4: 游走者与强化学习. (a) 随机游走者的参数更新, 由式 6.52 给出. (b) 在带目标游走者上训练的多种策略的演化.

参数更新是策略的二次函数:

$$\Delta\theta \propto \pi_{\theta}(\text{up})(1 - \pi_{\theta}(\text{up})). \quad (6.52)$$

它在接近最优策略 $\pi_{\theta}(\text{up}) \simeq 1$ 时和远离最优策略 $\pi_{\theta}(\text{up}) \simeq 0$ 时都取最小值, 如图 6.4(a) 所示. 这可以非常直观地理解: 若智能体已经优先选择向上移动, 那么它此后可学的东西就很少. 反之, 若它几乎不采取这一行动, 就无法学到这是正确选择. 因此, 当智能体以相近的频率采取两个行动时, 它学得最多. 这也反映了初始化的重要性. 若把策略初始化为 $\pi_{\theta_0}(\text{up}) \simeq 0$, 则智能体收敛到最优策略所需的时间, 比初始化为 $\pi_{\theta_0}(\text{up}) \simeq 0.5$ 时长得多.

现在考虑一种稍复杂的情形: 智能体沿一维路径移动, 并且必须停在一个目标位置. 此时, 两个行动是向前移动或停留. 智能体每在目标位置停留一个时步, 都会获得奖励. 在这个示例中, 最优策略是在智能体到达目标之前一直向前移动, 并在到达后停下.

与前一个示例不同, 智能体不再是盲目的, 策略确实依赖于状态. 注意, 尽管智能体在空间中移动, 其实际位置与问题完全无关; 唯一重要的信息是智能体是否处在正确位置. 因此, 我们用 Boolean 指示量编码这一信息: 智能体位于目标位置时令 $s = 1$, 在其他位置时令 $s = 0$. 所以, 尽管智能体在真实空间中移动, 它实际上只在一个二状态 MDP 中游历.¹⁹

随后, 我们分别用 $a = 0$ 和 $a = 1$ 表示“停留”与“移动”行动. 这样, 最优策略总是在不处于目标位置时采取移动行动, 而在处于目标位置时采取停留行动. 表 2 展示了这一最优策略. 此外, 图 6.4(b) 展示了用 REINFORCE 训练时多种策略向最优策略收敛的过程.

¹⁹需要强调的是, 将一个问题表述为强化学习实例时, 我们只需对与该问题有关的信息建模和编码. 因而, 由此得到的状态空间与行动空间不必直接对应于“现实世界”中的空间. MDP 越简单, 智能体面临的问题就越容易.

	停留 $a = 0$	移动 $a = 1$
不在目标处 $s = 0$	0	1
位于目标处 $s = 1$	1	0

表 2: 带目标游走者示例的最优策略 $\pi^*(a | s)$.

6.6.2 围棋和 Atari 游戏

游戏是强化学习最自然的应用之一，也是检验最先进方法的基准。大多数游戏都涉及长期策略，而且即使在很短的时间尺度内，早期行动也可能导致完全不同的结果。此外，许多游戏具有极其庞大甚至无限的状态空间。总体而言，它们构成了巨大的挑战，并推动了该领域若干最重要的进展。

人工智能最早在游戏中的应用对象是棋盘游戏。1997 年，基于知识的系统 *Deep Blue* [412] 击败了当时世界等级分最高的国际象棋棋手 Garry Kasparov，首次展现了超人类表现。较近的一项突破是在围棋中实现超人类表现 [30]。围棋是一种已有三千多年历史的中国棋盘游戏。两名棋手轮流在棋盘上落子，目标是通过有策略地围住空地或包围并提取对手棋子，占领尽可能大的空间。所有棋子都放置完毕后，占领地域最大的一方获胜。即使规则如此简单，棋盘也有 10^{172} 种可能布局，使围棋比国际象棋复杂许多个数量级 [413]。

DeepMind 开发的计算机程序 AlphaGo [30] 把一种称为 Monte Carlo 树搜索 (Monte Carlo tree search) [414] 的技术与深度神经网络结合起来。这一方法旨在逐步构建状态空间的搜索树；随着智能体积累经验，该树不断增长。树中的每条边都包含学得的行为价值函数 $Q(s, a)$ ，它与节 6.2.1 中的 Q-learning 类似，部分决定策略。然而，状态空间实际上是无限的，因此该方法实现了两个神经网络，引导搜索进入树外区域：参数化策略引导探索，而参数化价值函数预测从各状态出发的获胜概率。详细说明参见文献 [30]。

最初，他们利用专家棋局中的示例走法，以监督学习训练策略网络。与从白板状态开始构建搜索树相比，这使他们能够从已经有效的策略出发，获得早期优势。然而，随后他们通过自我博弈，即与自身对弈，训练整个流程，并如节 6.3 所示，通过策略梯度进一步改进策略。该模型于 2015 年击败了围棋世界冠军。

这一方案后来得到改进：去除以人类专家棋局进行的初始监督训练，完全从头开始通过自我博弈训练。该算法称为 AlphaGo Zero [415]。新版本以一百局全胜的成绩击败了先前版本。图 6.5 以 Elo 等级分展示了 AlphaGo 与 AlphaGo Zero 的表现随训练时间的变化。²⁰ 起初，AlphaGo 因先前的监督学习阶段而具有显著优势。然而，这种预训练最终限制了它的能力，AlphaGo Zero 只用数小时训练便超过了它。此外，这些算法通常针对特定游戏定制，而更新、更通用的方法则同时超越了国际象棋、日本将棋和围棋

²⁰Elo 等级分系统以其创立者 Arpad Elo 命名，是一种计算零和游戏中棋手相对技能水平的方法。每局比赛之后，胜者从负者处取得分数。两名棋手的等级分差决定一局之后获得或失去的总分数。若等级分较高的棋手获胜，只会从等级分较低者处取得少量分数；反之，等级分较低者会从等级分较高者处取得大量分数。




图 6.5: AlphaGo (先进行监督学习) [30] 与 AlphaGo Zero (纯强化学习) [415] 在围棋上的表现比较. 起初, AlphaGo 因预先进行的监督训练而占优. 然而, 这限制了它的能力, AlphaGo Zero 很快便超过了它. 水平虚线对应于 2016 年 3 月击败拥有 18 项国际冠军头衔的 Lee Sedol 的 AlphaGo 版本之 Elo 等级分, 可作为监督学习/纯强化学习表现的参照点. 引自文献 [415].

中的先前基准 [416].

电子游戏是强化学习在游戏中的另一个令人振奋的方向. 最早的一批应用之一是 Atari 游戏: 如节 6.2.3 所述, 深度 Q-learning 在其中实现了超人类表现 [28]. 此时, 状态空间同样是无限的, 智能体接收屏幕像素和当前分数作为输入. 不过, 行动空间受游戏控制器限制, 这对 Q-learning 十分便利. 同一个算法在 49 款不同游戏中实现了超人类表现.

电子游戏领域近期还有其他杰出成果. 智能体在 StarCraft II [29]、Dota 2 [417] 和 Minecraft [418] 中均达到了竞技水平. 此外, 无模型强化学习的进展推动了利用基于模型算法进行规划的研究; 这类算法已超越上文介绍的若干基准 [419]. 这一方案甚至不要要求显式编码游戏规则, 因为它会在游戏过程中建立规则模型.

6.6.3 量子反馈控制

量子控制是量子技术中的一个研究方向, 旨在改善目标量子态的初始化和稳定化. 深度强化学习算法已成功用于广泛的量子反馈控制应用 [421, 422, 423, 424]. 一般而言, 量子系统由强化学习智能体通过反馈回路控制, 在此过程中周期性地对系统进行测量. 这样, 智能体便依据测量结果驱动控制方案. 在文献 [422] 中, 作者考虑了一个单模量子腔. 腔模会发生泄漏, 并且可以测量这一信号. 如图 6.6 所示, 其目标是调节进入腔中的光束之外部驱动振幅, 以产生并稳定含单个光子的腔量子态.

智能体观测从腔中泄漏的测量电场, 这构成环境状态. 给定该观测后, 智能体可以设定驱动激光的振幅值. 系统在设定参数下演化一小段时间, 随后再次测量泄漏电场; 如此重复, 直至达到时间限制. 智能体采用节 6.3 所介绍的策略梯度方法训练. 在训练




图 6.6: 文献 [420] 提出的、作为强化学习环境的受驱动单模微腔. 腔模从腔中衰减, 其测量结果充当由神经网络表示的智能体之观测. 网络把一条测量轨迹转换为全部可用行动的概率; 这些行动为腔的位移驱动提供反馈.

过程中, 智能体最终找到一种策略, 以适当驱动来对抗损耗, 最后达到稳定的目标腔态.

6.6.4 量子电路优化

基于量子门的量子计算要求为特定量子算法设计量子电路. 然而, 实现同一算法的量子门序列可能有多种. 此外, 由于量子门的保真度并非完美, 执行的门操作越多, 算法运行过程中出现的错误就越多. 因此, 应以最优方式设计量子电路, 使用尽可能少的量子门. 这对含噪中等规模量子设备尤其重要: 这类设备目前可容纳 > 100 个量子比特 [425], 但同时无法实现高级逻辑量子纠错.²¹ 量子电路优化利用了如下事实: 存在一些变换规则集, 可以用输出相同的量子门序列替换原序列. 例如, 这些变换可以交换两个门的位置, 或相对于另一个门移动某个门的位置. 此外, 还可以在不改变输出的前提下合并门, 从而缩短某些门序列.

我们可以自然地把量子电路优化表述为强化学习问题 [426]. 在图 6.7 所示框架中, 环境保存量子电路, 其中包含不同量子门的信息, 例如它们的错误率. 智能体可以观测量子电路的一种表示, 此表示对应于状态; 智能体还可以从一组可能的变换规则中选择一种, 对电路进行变换. 环境能够评估变换后的电路, 并向智能体提供奖励. 奖励可以

²¹事实上, 我们将在节 6.6.5 中展示如何使用强化学习方法处理量子纠错.




图 6.7: 文献 [426] 提出的电路优化强化学习框架示意图. 智能体观测环境给出的量子电路表示, 随后可以选择修改该电路. 环境根据所得电路的门数 (或其他度量) 计算奖励, 并把新电路和奖励提供给智能体.

计入多个方面, 例如总门数的减少、电路深度 (电路运行所需时间) 的降低, 或二者的组合. 此外, 奖励函数还可以依赖对整个电路的退相干估计, 而该估计基于各量子门上发生的退相干.

这样, 所得电路优化便成为一个自主过程, 在选择行动时能够计入硬件的特定信息; 例如, 一些门需要更长的执行时间, 某个给定量子比特也可能比其他量子比特更容易出错. 未来, 量子编译器将能够针对硬件规格与原生门实现来优化电路.

6.6.5 量子纠错

每当执行任何类型的计算时, 我们都必须确保计算无误. 无论经典计算还是量子计算, 都需要某种机制来减轻计算过程中可能出现的错误所造成的影响. 经典纠错方法早已确立, 而当前的量子纠错方案却需要数量惊人的额外量子比特. 此外, 经典纠错方案无法直接迁移到量子情形, 因为我们既不能简单地复制任意量子态 (这就是不可克隆定理 [427]), 也不能为了查找可能的错误而任意测量量子计算机的状态, 否则会抹去该状态的叠加. 一些纠错实现利用强化学习方法应对这些挑战. 下面讨论两种不同的方法.




图 6.8: 文献 [422] 提出的基于强化学习的纠错框架示意图. 为了保护一个目标量子比特, 智能体可以选择下一项门操作或测量, 并将其施加于由少数几个可能受错误影响的量子比特组成的系统.

如图 6.8 所示, 第一种方法仅通过与一组量子比特相互作用, 从零开始提出合适的纠错方案 [422]. 这种方法把实际硬件视为黑箱, 不要求关于任务的任何先验知识, 因而可以灵活适应硬件约束. 在此设定中, 目标是在一段时间内保持任意单量子比特态 $|\phi(0)\rangle = \alpha|0\rangle + \beta|1\rangle$. 为此, 智能体可以选择施加给定集合中的门, 或对辅助量子比特执行测量. 这样, 只要适当选择构成行动空间的可用门, 便能直接纳入任何硬件限制. 随后, 可以用某个任意但固定的时刻 T 后的保真度 $F = |\langle\phi(T)|\phi(0)\rangle| \in [0, 1]$ 衡量性能.

然而, 如果只把保真度作为奖励, 朴素的强化学习方法注定会失败. 几乎所有可能的电路变换都会降低保真度, 因而随机策略甚至不如保持空闲. 即使在每次加入新门或测量后都考察保真度, 也会出现这种情况, 因为最优方案起初会降低保真度, 随后才施加恢复序列使其复原. 因此, 当时间 T 很大时, 找到能保护该状态的正确门序列的概率趋于零. 为克服这些困难, 文献 [422] 提出了两阶段学习方案和一种更便利的奖励函数.

两阶段学习需要训练两个模型. 首先, 训练一个强化学习智能体; 相较于真实设备上可获得的信息, 它可以访问增强信息, 例如多量子比特态的完整描述. 这也允许我们采用一种更便利的奖励函数, 即可恢复量子信息 (recoverable quantum information)

$$r_t = \frac{1}{2} \min_{\vec{n}} \|\hat{\rho}_{\vec{n}}(t) - \hat{\rho}_{-\vec{n}}(t)\|_1. \quad (6.53)$$

其中, $\vec{n}$ 表示 Bloch 球中对应于初态的向量. 这种奖励利用 $\vec{n}$ 与 $-\vec{n}$ 正交这一事实, 在每个时步提供奖励, 引导智能体找到最优门序列. 细节见文献 [422].

随后, 以第一个模型为教师训练第二个模型. 第二个模型只能访问真实设备中可获得的信息, 例如它施加的门和偶尔取得的测量结果. 我们不用强化学习训练它, 而是采用监督方式, 使其模仿第一个模型的行为. 这一过程类似于训练监督分类器, 其中标签是第一个模型采取的行动.

两阶段学习的总体过程快得多, 计算需求也远低于直接求解原问题. 其主要局限是教师模型需要多量子比特系统的完整状态描述, 这把应用限制在少量量子比特上; 它还要求设备具有充分表征的噪声映射, 而实践中可能并不知道这种映射.

第一种方法旨在通过直接的量子比特相互作用发现最佳纠错方案, 第二种方法则实现量子码来表示逻辑量子比特 [428, 429, 430]. 在这里考察的例子 [431] 中, 作者利用稳定子码通过冗余实现纠错. 为正确理解这一过程, 先对稳定子形式体系建立一些基本直觉. 考虑一种初步的编码, 它用于纠正物理量子比特的任意单次比特翻转 $|0\rangle \leftrightarrow |1\rangle$:

$$|0_L\rangle = \frac{1}{\sqrt{2}} (|000\rangle + |111\rangle).$$

它用三个物理量子比特表示单个逻辑量子比特态 $|0_L\rangle$. 借助稳定子操作 (stabilizer operation), 可以在不改变状态的情况下联合测量量子比特的子集. 在本例中, 可以施加操作 $Z_1 Z_2$ 和 $Z_2 Z_3$ 而不改变量子比特态: $Z_1 Z_2 |0_L\rangle = |0_L\rangle = Z_2 Z_3 |0_L\rangle$. 此外, 还可以用这些算符检测某个物理量子比特上的比特翻转错误, 因为稳定子算符的设计也不会改变出错后的状态.²² 稳定子测量的结果为 ± 1 ; 依次施加这些测量, 就能判断是否有量子比特发生错误, 进而执行纠正. 这一系列结果称为错误症状 (syndrome), 而在实践中, 症状本身也可能出错.

在这个例子中, 我们能够处理单次比特翻转错误, 却不能处理由 Z_i 算符表示的相位错误. 要纠正任意单量子比特错误, 需要五个物理量子比特和四个稳定子操作 [430]. 随着需要覆盖的量子比特错误类别增多, 量子比特开销会迅速增长. 文献 [431] 中的稳定子码是一种表面码 (surface code): 它使用至多 d^2 个物理量子比特, 保护单个逻辑量子比特免受最多影响 d 个量子比特的任意错误.

要正确执行纠错, 需要兼具精度、可扩展性以及检测和纠正错误的速度. 我们可以利用本章介绍的全部工具, 把它表述为强化学习任务 [432, 433, 431, 434]. 在文献 [431] 的设定中, 环境跟踪底层量子态, 并计入物理量子比特上可能出现的随机错误, 其形式

²²实践中, 我们会先设计一组稳定子算符, 再把逻辑 0 态和 1 态定义为所有稳定子的共同本征态.

为退极化噪声和比特翻转噪声. 智能体可以选择执行单量子比特 X 、 Y 或 Z 旋转,²³也可以执行症状测量. 随后, 环境向智能体提供可能有误的测量结果和奖励, 智能体据此决定下一组行动. 环境采用裁判解码器 (referee decoder), 检查智能体采取行动后的多量子比特态是否对应同一逻辑量子比特态. 若是, 奖励为正; 否则奖励为负, 回合终止.

文献 [431] 采用基于 DQN 的智能体, 并使用我们在节 6.2.3 中介绍的 Q-learning 算法训练它. 训练后, 编码逻辑量子比特的平均寿命可以显著延长, 如图 6.9 所示.

此外, 作者还在上述框架内实现了另一种遗传算法, 得到的机器学习模型小得多, 更适合在实际设备上运行.




图 6.9: 用表面码编码的逻辑量子比特的平均寿命. 物理量子比特受到参数为 p_{phys} 的退极化噪声影响, 这会显著缩短无保护量子比特的寿命 (黑线). 使用在不同噪声水平 p_{phys} 下训练的智能体, 可以大幅延长量子比特寿命 (蓝点). 引自文献 [431].

6.6.6 量子实验设计

新实验的设计是量子科学发展的关键. 应用越复杂, 就越难找到合适的装置来检验我们的想法. 在量子物理学中, 光学实验很好地说明了这一点: 我们组合不同元件, 使最终量子态具有某些期望性质. 例如, 寻找合适的元件集合以产生高维多体纠缠是一项并非易事的任务, 通常依赖关于量子态的深厚先验知识和复杂的数学方法 [435]. 然而, 这类状态对量子信息与量子计算应用十分重要, 因而备受重视.

文献 [375] 采用我们在节 6.5 中介绍的投影模拟算法, 提出了一种利用强化学习自主构建实验的方法. 其目标是基于光的轨道角动量产生高维多粒子纠缠态. 为此, 智能体可以使用一组光学元件; 行动是在光学平台上放置其中一个元件, 而状态则是平台上光学元件的不同配置. 每放置一个元件, 环境都会分析该装置所产生的量子态. 若它对应于期望量子态, 环境便向智能体提供奖励并结束回合; 否则, 智能体继续放置更多元件. 需要注意的是, 由于光学装置中存在噪声, 元件越多, 就越难正确找到目标量子态.

²³由于 $XZ = iY$, 在某些情形中可以缩小行动空间.

因此，智能体必须在给定的最大元件数内达到目标；超过这一数量后，回合结束，平台重置。

从技术角度看，智能体具有两层 ECM：一层表示平台配置（状态），另一层表示光学元件（行动）。投影模拟的一个有趣特性是行动组合（action composition）：智能体可以用先前回合中发现有用的简单行动创建新的复合行动。在当前语境下，如果智能体找到一串能够带来奖励的有利行动，就可以把这些行动组合成一个新的单一行动并加入 ECM，从而使智能体只需一步决策便能访问受奖励的实验。这样，智能体既可以提炼出产生光学干涉仪等已知装置的元件组合，也可以发现全新的装置，例如 Mach-Zehnder 干涉仪的非局域版本。

因此，可以把生成量子态的一般任务分为两部分：寻找产生目标态的最简单光学配置，以及寻找尽可能多的能够产生该状态的实验。前者对量子技术的实际应用至关重要，因为较短的实验噪声更小，通常也更容易实现。后者使我们能够充分探索问题的所有可能解，从而可能发现产生期望量子态的新方法。

人们也采用非强化学习方法研究了量子光学实验的自动设计 [436, 437, 438]。我们将在节 7.3.4 中更详细地介绍这些方法。

6.6.7 构建最优松弛

在物理学中，我们经常遇到无法在合理时间内求解的优化任务。此时，需要依靠近似方法，获得尽可能接近精确解的结果。有两种典型方法：变分方法和松弛方法（relaxation method）。前者参数化一个解族，并希望其中包含精确解，例如章 5 介绍的变分量子态。后者则构建问题的一个较易求解的松弛版本，使优化过程具备凸性等理想性质。




图 6.10: 寻找最优松弛的强化学习框架示意图. 智能体可以通过行动修改问题的有效约束集合. 这些约束进入环境, 由环境求解带约束的优化问题. 随后, 智能体观测一个同时依赖问题求解结果和环境所付计算代价的奖励, 并可根据这一观测决定是否进一步修改约束.

松弛方法广泛用于量子物理学, 并位于量子信息处理的核心. 纠缠理论中最典型的例子之一, 是把可分态集合松弛为正偏转置 (positive partial transpose, PPT) 态集合 [439]. 判断一个状态是否属于前一集合很困难, 而检查它是否属于后一集合则十分直接. 这大大简化了判断状态是否纠缠的问题: 只需检查它不是 PPT 态即可. 然而, 虽然所有乘积态都是 PPT 态, 却也有一些纠缠态属于该集合, 因此 PPT 态集合构成可分态集合的外逼近.

与变分方法类似, 我们经常要在可承受的计算代价和方法精度之间作出权衡. 因此, 在计算预算有限时, 找到最接近最优解的松弛至关重要. 然而, 并没有明确的方法预先知道这种最优松弛. 最常见的做法是利用给定问题的特定知识 (例如对称性) 来手工构造松弛, 而这些松弛通常是次优的. 不过, 可以把强化学习与半定规划 (semidefinite programming) 结合起来, 系统地构建最优松弛 [440].

构建松弛的一种自然方式, 是移除或放松当前优化问题的约束. 在图 6.10 所示的强化学习框架中, 状态编码问题的有效约束, 智能体可以通过行动放松或加强这些约束. 环境充当黑箱, 把与行动相联系的奖励以及新状态 (即新的约束集合) 提供给智能体. 奖励经过设计, 同时评价当前松弛的质量与代价, 从而引导智能体走向最优松弛.

强化学习智能体完全不了解问题的具体内容. 因此, 该方法可用于物理学和优化中

的多种相关问题，例如构造纠缠见证、优化量子关联集合的外逼近，或寻找多元多项式更好的平方和表示。文献 [440] 展示了两项应用：寻找量子多体 Hamiltonian 的基态能量，以及构造基于能量的纠缠见证。从所得最优松弛中可以推断系统性质，例如基态的变化；更进一步，还可以利用迁移学习自主探索相图。

6.7 展望与开放问题

本章介绍了强化学习领域及其主要范式，包括基于价值的强化学习（节 6.2）、策略梯度方法（节 6.3）和演员-评论家算法（节 6.4）。此外，我们还考察了其他强化学习途径，例如投影模拟算法（节 6.5）。这些内容奠定了理解众多其他高级强化学习技术的概念基础；与此同时，如节 6.6 所示，它们本身已经具有竞争力。

在量子技术领域，强化学习已广泛用于量子控制问题，尤其是量子模拟。随着当前量子计算的蓬勃发展，许多涉及状态制备、纠错以及量子比特控制与制备的问题，都可以自然地映射到强化学习框架 [441, 442, 443, 444, 445, 446, 447, 448]。此外，强化学习还能作为结构清晰的大型问题之优化工具，其应用包括量子电路优化、实验装置设计以及量子信息处理问题中松弛的构造等诸多方面。

与无监督学习类似，强化学习是一种颇具吸引力的自主科学发现（autonomous scientific discovery）技术，因为它不需要显式给出经过完整刻画的学习实例。不过，尽管我们能够在强化学习应用的结果中辨认出一些先前已知的策略，例如节 6.6.4 中的例子，但仍需发展进一步的分析技术，才能充分理解某些突出结果的性质及其背后的原理。

强化学习算法领域的一项重大关切是数据效率（data efficiency），它对涉及高成本实验或模拟的应用至关重要。在这方面，强化学习领域可以从物理学的最新进展中受益匪浅，例如为最具挑战性的问题设计最优探索策略，或利用量子技术的最新进展增强强化学习，正如我们将在 paragraph 8.2.7 中展示的那样。

延伸阅读

1. Sutton, S. R. & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. 这部教材对强化学习作了全面综述 [378]。其中，第 7 章和第 12 章进一步展开了时序差分概念，第 13 章则完整补充推导了策略梯度、演员-评论家方法及其在持续性问题（无限时域）中的应用。
2. Marquardt, F. (2021). *Machine learning and quantum devices*. *SciPost Phys. Lect. Notes* 29. 面向物理学家的强化学习导论 [420]。
3. Silver, D. et al. (2014). *Deterministic policy gradient algorithms*. PMLR, 387–395 [449]。我们在节 6.3 中介绍的策略梯度方法采用随机策略；本文则引入采用确定性策略的策略梯度，以及它在演员-评论家算法中的相应实现。
4. 当前一些最先进的算法，例如我们在节 6.4 末尾提到的算法，会在目标函数中加入额外项，通常取熵或 Kullback–Leibler (KL) 散度的形式。这会产生更稳健的算法，并与把强化学习表述为概率推断密切相关。关于教程，推荐阅读文献 [450]；关于一种代表性算法，见文献 [451]；关于另一种算法及对该领域的出色概述，见文献 [452]。后一种算法已经在核聚变反应堆的实验控制中证明了其性能 [453]。
5. 强化学习在量子技术中最突出的应用包括量子控制和量子纠错。若要深入了解量子控制，推荐阅读文献 [454]，其中给出了不同于节 6.6.3 所述方案的另一种无模型方案。作者提出了一个便于实验实现、可直接用于超导电路和囚禁离子平台的强化学习框架。在量子纠错方面，推荐阅读文献 [455]；这项开创性工作超导量子器件中展示了一个完全稳定并经过纠错的逻辑量子比特。作者使用由强化学习训练的纠错方案，显著延长了逻辑量子比特的相干时间。

量子科学中的深度学习专题




图 7.1: 机器学习与物理学之间存在双向关系. 本章关注较为常见的方向, 即使用机器学习技术, 特别是深度学习, 求解物理学问题.

到目前为止, 本书聚焦于量子科学与机器学习交叉领域中的四个宽广方向: 章 3 中使用无监督和监督机器学习方法进行相分类; 章 4 中特别面向量子化学使用核方法; 章 5 中使用机器学习模型表示量子态; 以及章 6 中在量子科学里使用强化学习. 我们在(希望足够全面的)介绍之后, 详细讨论了每一个方向. 因而, 从章 3 到章 6 展示了机器学习在量子科学中的大量应用. 然而, 它们显然并未构成对该领域的完整综述.

为弥补这些空缺, 接下来的两章旨在讨论机器学习与量子科学交叉领域中更专门的主体. 本章尤其进一步讨论如何用机器学习求解量子科学问题(见图 7.1). 首先, 我们将在节 7.1 中解释可微编程的概念及其在量子科学中的用例. 节 7.2 介绍生成模型, 以及它们如何处理量子物理学中的密度估计问题. 最后, 我们将在节 7.3 中介绍面向实验装置的若干机器学习应用.

7.1 可微编程

可微编程 (differentiable programming) 是从深度学习中兴起的软件开发范式的一次根本转变 [456]. 在“标准”编程中, 每条指令都在代码里显式指定, 也就是说, 我们在具有某种期望行为的程序空间 (program space) 中指定一个点 (见图 7.2). 而在可微编程中, 计算机程序由可以调整的参数化代码元素组成. 程序员通过损失函数指定程序的期望行为, 随后利用导数信息调节代码参数, 使给定损失函数最小, 从而在程序空间中搜索合适的程序. 本书反复遇到的例子是使用反向传播高效调节神经网络参数, 以求解给定任务, 例如对不同物质相进行分类, 或表示量子多体系统的基态波函数.

在大多数现实问题中, 收集已经正确完成给定任务的实例数据, 往往比编写一个解

决该任务的程序更容易。在这种情况下，可微编程尤其出色，因为它使解决任务的程序能够从数据中**学习**得到。深度学习所生成程序的成功表明，这种方法可以极为强大。事实上，正如本书已经广泛讨论的那样，如今可微编程在许多实例中产生的算法都能轻松超越人类，例如 AlphaGo [30]。

与传统编程相比，可微编程还有许多其他优势。其中一个方面是可以开发定制优化策略。神经网络的典型指令集由矩阵乘法、向量加法和逐元素应用非线性函数组成；与整个标准计算机程序类别所对应的指令集相比，这一集合有限且小得多。因而，可以针对可微编程底层的有限指令集设计优化硬件，以实现计算加速。图形处理器 (graphics processing unit, GPU) 和张量处理器 (tensor processing unit, TPU) 就是这类专用硬件 (application-specific hardware) 的例子。最近，神经形态计算 (neuromorphic computing) 作为一种新范式兴起；它通过模拟大脑神经元与突触计算的硬件系统，为机器智能带来更快、更节能的计算 [457, 458]。

可微编程也使编程更加灵活：设想已有一段执行某项任务的标准代码，现在有人要求你把它加速一倍，代价可以是牺牲一定精度。这会是一项极不平凡的任务。然而，在可微编程中，可以借助代价函数和超参数轻松纳入这类约束。例如，若使用神经网络，可以把网络规模缩小一半并重新训练。再设想把起初分别优化或编写的程序以模块化方式合并，形成一个新的更大程序。此时，可微编程为优化新程序的性能提供了一种简单方案：通过优化，对给定配置中的各个组件作微调。可微编程的优势以程序可解释性为代价。优化结束时，我们会得到运行良好，却很难由人类阅读和直观理解的代码。因此，我们通常必须在两者之间选择：一种是人类能够理解、精度尚可的模型；另一种则更精确，却难以解释。¹

在可微编程中，可以自动对任意计算机程序结构求导。重要的是，这使神经网络能够嵌入众多已有的科学模拟和计算，因为训练神经网络所需的梯度可以高效计算。特别地，既可以贯穿神经网络求导，也可以贯穿程序中包围它的非参数化、不可训练部分求导。

近年来，可微编程在科学计算领域引起了广泛关注 [459]。已经以完全可微方式编写的算法包括 Fourier 变换、特征值求解器、奇异值分解和常微分方程 [460, 461]。因而，可以贯穿特定领域的计算过程求导，以求解学习或控制任务等逆问题：张量网络 [462, 463, 464]、分子动力学 [465, 466]、量子化学 [467, 468, 469, 470, 471, 472, 473, 474, 475, 476]、量子最优控制 [477, 478, 479, 480, 481, 482, 483, 484, 485, 486, 487, 488] 和量子电路 [489, 490] 都已经具有完全可微的表述。我们将在节 7.1.2 中详细讨论若干例子。

值得注意的是，可微编程促成了科学机器学习 (scientific machine learning)，它结合了两方面的优势：一般而言，黑箱机器学习方法很灵活，但需要大量数据才能成功训练。把我们关于问题结构的科学知识纳入程序，可以减少所需数据量。随后借助可微编程训练程序中的参数化部分。这样，只需学习模型中“缺失”的部分，学习任务便得到简化。

可微编程最重要的成就或许是能够计算损失函数关于神经网络参数的梯度（见节 2.5）。回顾一下，使用基于梯度的优化器训练神经网络时（通常如此），我们需

¹可解释性再次成为核心问题（见节 3.5）。




图 7.2: “标准”编程与可微编程之差异的示意图. 在某些情况下, 可微编程找到的程序之复杂度会超出人类能力. 启发自文献 [456].

要这些梯度. 关键在于, 这一计算高效、精确且自动进行. 特别地, 它可以自动对任意神经网络架构求导, 无需额外实现工作. 相比之下, 繁琐的解析梯度计算在神经网络架构改变后必须重新进行.

不过, 可微编程并不限于为神经网络训练计算关于神经网络参数的梯度. 它还能自动计算任意程序变量的梯度和高阶导数. 例如, 这些变量可以是某个 Hamiltonian 的可调参数, 而我们对该 Hamiltonian 的基态感兴趣. 由于能够贯穿特征值求解器求导, 可以用基于导数的优化器调节 Hamiltonian 参数, 使其基态满足由损失函数指定的期望性质; 详见节 7.1.2. 这是一个能够通过可微编程高效求解的逆问题. 然而, 可微编程的适用范围不止于求解优化任务. 梯度和高阶导数包含模型参数与输出之间关系的宝贵信息, 例如, 它们可以帮助解释相分类方法 [164] (见节 3.5.3), 或帮助刻画变分量子电路 [491].

7.1.1 自动微分

可微编程使我们能够计算任意计算机程序的梯度和高阶导数.

一般而言，计算机程序中计算导数的方法可以分为四类 [492]：

1. 手工推导导数并将其编码，即手工微分 (manual differentiation)；
2. 使用有限差分近似的数值微分 (numerical differentiation)；
3. 通过表达式操作进行的符号微分 (symbolic differentiation) ^a；
4. 作为可微编程核心工具的自动微分 (AD)。

^a这由 Mathematica、Maxima 或 Maple 等计算机代数系统完成。

下面简要讨论这些不同方法。

手工微分既耗时又容易出错。数值微分的实现相当简单。其最基本的形式基于导数的极限定义：给定多元函数 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ ，其梯度 $\nabla f = (\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_m})$ 的各分量可近似为

$$\left. \frac{\partial f}{\partial x_i} \right|_x \approx \frac{f(\mathbf{x} + h\mathbf{e}_i) - f(\mathbf{x})}{h}, \quad (7.1)$$

其中 $\mathbf{e}_i \in \mathbb{R}^m$ 是第 i 个单位向量， h 是很小的步长。以这种方式近似 ∇f 需要对 f 求值 $\mathcal{O}(m)$ 次。这是数值微分在机器学习中并不实用的主要原因，因为可训练参数的数量 m 可能高达数百万乃至数十亿。还要注意，为使梯度近似较为准确，必须谨慎选择步长 h ：当 $h \rightarrow 0$ 时，式 7.1 中近似的截断误差 (truncation error) 可以任意小，但最终由浮点算术 (floating-point arithmetic) 引起的舍入误差 (round-off error) 会主导计算。²

符号微分是对数学表达式进行自动操作，以获得显式的导数表达式；例如，可以使用乘积法则这样的简单求导规则：

$$\frac{d}{dx}(f(x)g(x)) = \frac{df(x)}{dx}g(x) + f(x)\frac{dg(x)}{dx}. \quad (7.2)$$

符号表达式具有可解释的优点，也使问题能够得到解析处理。然而，由符号微分生成的符号导数通常无法高效计算导数值，因为它们很快就会变得远大于其所表示导数的原表达式。考虑形如 $h(x) = f(x)g(x)$ 的函数及其导数，后者可利用式 7.2 中的乘积法则求值。注意，例如 $f(x)$ 和 $\frac{df(x)}{dx}$ 在这一表达式中分别出现。因此，按照式 7.2 朴素地计算导数，会重复计算同时出现在 $f(x)$ 与 $\frac{df(x)}{dx}$ 中的任何表达式。此外，手工方法和符号方法要求底层函数由闭式表达式定义。因而，它们难以处理含有条件分支、循环或递归的程序。这意味着，要使符号微分高效，必须存在便于计算所考虑导数的符号表达式。

当我们关心导数的精确数值求值而非其符号形式时，可以把中间子表达式的值存入内存，从而显著简化计算。这正是自动微分 (AD) 背后的基本思想。AD 给出导数的数值（而不是符号表达式），并利用符号求导规则做到这一点（不过，它跟踪的是导数值，而不是整个符号表达式）。因此，可以把它视为数值微分与符号微分之间的中间方法。AD 利用了如下事实：无论计算机程序看起来多么复杂，它都只是在执行一系列基本算

²在计算中，浮点数通常以有限个有效数字近似表示，并通过某个固定底数的指数加以缩放，即 $a \times b^c$ ，其中 a 、 b 和 c 均为整数。由于可表示的数目有限，执行计算时可能产生舍入误差。




图 7.3: 函数 $f(x_1, x_2) = \ln(x_1) + \cos(x_2) - x_1x_2$ 的前向求值轨迹所对应的计算图.

术运算（例如加法或乘法）和基本函数（例如 $\exp$ 或 $\sin$ ）. 我们把计算机程序为从输入值计算输出值而应用的基本运算序列称为求值轨迹（evaluation trace）[493]. 因而，通过反复应用链式法则，可以自动计算任意计算机程序的导数. 所以，计算导数所需的算术运算次数与原程序处于同一量级. 此外，这样得到的导数可精确到机器精度（machine precision）. 下面说明在实践中如何实施 AD.

从概念上说，所谓前向模式 AD（forward-mode automatic differentiation）是最简单的一类 AD. 考虑函数

$$f(x_1, x_2) = \ln(x_1) + \cos(x_2) - x_1x_2 \quad (7.3)$$

的求值轨迹，如表 3 左栏所示. 相应的计算图（computation graph）见图 7.3，其中函数 f 的计算被分解为变量 v_i . 我们采用文献 [494] 中的标准记号： v_{1-i} ($i = 1, \dots, n$) 是输入变量， v_i ($i = 1, \dots, l$) 是中间变量，而 v_{l+i} ($i = 1, \dots, m$) 是输出变量. 为计算 f 关于 x_1 的导数，我们首先为每个变量 v_i 关联一个导数

$$\dot{v}_i = \frac{\partial v_i}{\partial x_1}. \quad (7.4)$$

对求值轨迹中的每个基本运算应用链式法则，即可生成相应的导数轨迹（derivative trace），见表 3 右栏. 在前向模式 AD 中，通过同步计算中间变量 v_i 及其对应导数 $\dot{v}_i$ ，得到所需导数 $\dot{v}_5 = \frac{\partial y}{\partial x_1}$ ，其中 y 是输出变量.

$v_{-1} = x_1$	$= 2$	$\dot{v}_{-1} = \dot{x}_1$	$= 1$
$v_0 = x_2$	$= 1$	$\dot{v}_0 = \dot{x}_2$	$= 0$
$v_1 = \ln v_{-1}$	$= \ln 2$	$\dot{v}_1 = \dot{v}_{-1}/v_{-1}$	$= 1/2$
$v_2 = v_{-1}v_0$	$= 2$	$\dot{v}_2 = \dot{v}_{-1}v_0 + \dot{v}_{-1}\dot{v}_0$	$= 1$
$v_3 = \cos v_0$	$= \cos 1$	$\dot{v}_3 = -\dot{v}_0 \sin v_0$	$= 0$
$v_4 = v_1 - v_2$	$= -1.307$	$\dot{v}_4 = \dot{v}_1 - \dot{v}_2$	$= -1/2$
$v_5 = v_3 + v_4$	$= -0.767$	$\dot{v}_5 = \dot{v}_3 + \dot{v}_4$	$= -1/2$
$v_5 = y$	$= -0.767$	$\dot{v}_5 = \dot{y}$	$= -1/2$

表 3: 对函数 $f(x_1, x_2) = \ln(x_1) + \cos(x_2) - x_1x_2$ 计算前向模式 AD 导数的流程. 左：初始输入取 $(x_1, x_2) = (2, 1)$ 时的前向求值轨迹. 右：前向导数轨迹，得到 $(x_1, x_2) = (2, 1)$ 处的 $\frac{\partial f}{\partial x_1}$.

这一过程可以推广到计算函数 $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ 的完整 Jacobian 矩阵, 其中有 m 个输入变量 x_i 和 n 个输出变量 y_j . 在这种情况下, AD 的每次前向遍历都通过把单个变量的 $\dot{x}_i$ 设为 1、其余变量的相应值设为零来初始化. 也就是说, 我们选择 $\dot{\mathbf{x}} = \mathbf{e}_i$, 其中 $\mathbf{e}_i$ 是第 i 个单位向量. 对给定输入值 $\mathbf{x} = \mathbf{a}$ 的前向遍历随后计算

$$\dot{y}_j = \left. \frac{\partial y_j}{\partial x_i} \right|_{\mathbf{x}=\mathbf{a}} \quad \text{对于 } j = 1, \dots, n. \quad (7.5)$$

这对应于 Jacobian 矩阵的第 i 列:

$$J_f = \left[\begin{array}{ccc} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \cdots & \frac{\partial y_n}{\partial x_m} \end{array} \right]_{\mathbf{x}=\mathbf{a}}. \quad (7.6)$$

因此, 完整 Jacobian 可以用 m 次前向遍历计算, 即对函数 f 求值 m 次. 所以, 当 $m \ll n$ 时, 前向模式 AD 是高效的. 在另一个极限下, 则优先采用所谓的反向模式 AD, 我们很快会讨论它.

在实践中, 前向模式 AD 通过扩充实数代数并引入一种新算术来实现: 为每个数关联一个附加分量, 它对应于函数在该特定值处计算得到的导数. 我们把这个复合数称为双数 (dual number):

$$\text{dual}(v) = v + \dot{v}\epsilon, \quad (7.7)$$

其中 $\epsilon \neq 0$ 且 $\epsilon^2 = 0$. 把所有算术算子扩展到双数, 便可定义双数代数. 例如, 注意

$$f(\text{dual}(v)) = f(v) + \dot{f}(v)\dot{v}\epsilon, \quad (7.8)$$

其中, 第一部分给出函数值, ϵ 部分给出相应导数 $\dot{f}(v)\dot{v}$.³ 这可由展开函数的 Taylor 级数看出: 由于 $\epsilon^2 = 0$, $\mathcal{O}(\epsilon^2)$ 项消失. 式 7.8 类似于利用链式法则计算导数.

顾名思义, 在反向模式 AD (reverse-mode automatic differentiation) 中, 导数从给定输出开始反向传播.⁴ 这与前向模式 AD 形成对照; 我们已经看到, 在前向模式中, 导数与函数求值同步向前传播. 实施反向模式 AD 时, 要为每个中间变量 v_i 补充一个所谓的伴随量 (adjoint):

$$\bar{v}_i = \frac{\partial y_j}{\partial v_i}, \quad (7.9)$$

其中 y_j 是我们希望对其计算导数的输出变量. 在反向模式 AD 中, 导数在两阶段过程的第二阶段计算. 第一阶段向前运行原函数代码: 填充中间变量 v_i , 并通过记录过程跟踪它们在计算图中的依赖关系. 第二阶段通过反向传播伴随量 $\bar{v}_i$ 来计算导数, 即从输出传播到输入. 对于式 7.3 给出的函数, 表 4 展示了这一过程; 反向遍历以 $\bar{v}_5 = \bar{y} = \frac{\partial y}{\partial y} = 1$ 开始. 结果是, 一次反向遍历便同时得到 $\bar{x}_1 = \frac{\partial y}{\partial x_1}$ 和 $\bar{x}_2 = \frac{\partial y}{\partial x_2}$.

³在底层, 双数通常通过所谓的算子重载 (operator overloading) 来处理, 也就是重载所有函数, 使其能在新代数上适当地工作.

⁴从历史上看, 反向模式 AD 可以追溯到 Seppo Linnainmaa 1970 年的硕士论文 [495]; 他在其中描述了任意离散、可能稀疏连接、类似神经网络的网络中显式而高效的误差反向传播 [496].

$v_{-1} = x_1$	$= 2$	$\bar{v}_5 = \bar{y}$	$= 1$
$v_0 = x_2$	$= 1$		
$v_1 = \ln v_{-1}$	$= \ln 2$	$\bar{v}_4 = \frac{\partial v_5}{\partial v_4} \bar{v}_5 = \frac{\partial(v_3 + v_4)}{\partial v_4} \bar{v}_5$	$= 1$
$v_2 = v_{-1} v_0$	$= 2$	$\bar{v}_3 = \frac{\partial v_5}{\partial v_3} \bar{v}_5$	$= 1$
$v_3 = \cos v_0$	$= \cos 1$	$\bar{v}_2 = \frac{\partial v_4}{\partial v_2} \bar{v}_4$	$= -1$
$v_4 = v_1 - v_2$	$= -1.307$	$\bar{v}_1 = \frac{\partial v_4}{\partial v_1} \bar{v}_4$	$= 1$
$v_5 = v_3 + v_4$	$= -0.767$	$\bar{v}_0 = \frac{\partial v_2}{\partial v_0} \bar{v}_2 + \frac{\partial v_3}{\partial v_0} \bar{v}_3$	$= -2.841$
		$\bar{v}_{-1} = \frac{\partial v_1}{\partial v_{-1}} \bar{v}_1 + \frac{\partial v_2}{\partial v_{-1}} \bar{v}_2$	$= -1/2$
$v_5 = y$	$= -0.767$	$\bar{v}_0 = \bar{x}_2$	$= -2.841$
		$\bar{v}_{-1} = \bar{x}_1$	$= -1/2$

表 4: 对函数 $f(x_1, x_2) = \ln(x_1) + \cos(x_2) - x_1 x_2$ 计算反向模式 AD 导数的流程. 左: 初始输入取 $(x_1, x_2) = (2, 1)$ 时的前向求值轨迹. 右: 反向 (伴随) 导数轨迹, 得到 $(x_1, x_2) = (2, 1)$ 处的 $\frac{\partial f}{\partial x_1}$ 和 $\frac{\partial f}{\partial x_2}$.

这个例子说明了反向模式与前向模式的互补性: 对于输入数量很多的函数, 即 $f: \mathbb{R}^m \rightarrow \mathbb{R}^n$ 且 $m \gg n$ 时, 反向模式的求值成本低于前向模式. 正如刚才所见, 在 $f: \mathbb{R}^m \rightarrow \mathbb{R}$ 这一极端情形下, 反向模式只需应用一次即可计算完整梯度, 而前向模式需要遍历 m 次. 机器学习应用中的典型情形, 是计算损失函数 $y_j = \mathcal{L}: \mathbb{R}^m \rightarrow \mathbb{R}$ 关于 m 个可训练参数的导数, 其中 m 通常很大. 因此, 反向模式 AD 的计算效率高于前向模式 AD, 是自动计算梯度的首选方法.⁵ 在机器学习语境中, 把反向模式 AD 应用于神经网络通常称为反向传播, 见节 2.5. 它是神经网络训练背后的核心工具, 因为它能够以自动方式高效计算任意基于神经网络的架构的梯度. 下面讨论反向模式 AD 在实践中的若干实现方式.

静态图 AD 反向模式 AD 的一种基本实现使用静态计算图 (static computation graph). 鉴于我们选择用计算图说明反向模式 AD, 这一选择很自然 [497]. TensorFlow 是采用这种方法的平台之一. 在这里, 用户必须用基于图的语言 (graph-based language) 定义变量和运算. 随后执行计算图时, 便可直接对程序求导. 然而, 这要求把所有已有程序都重写为静态计算图, 因而并不方便.

⁵注意, 前向模式与反向模式 AD 只是应用链式法则的两种 (极端) 方式. 对于给定函数, 寻找遍历链式法则以计算 Jacobian 的最优方式, 即使算术运算次数最少的选择, 称为最优 Jacobian 累积问题 (optimal Jacobian accumulation problem), 它是 NP-完全 (NP-complete) 的.

基于追踪的 AD 这一限制可通过在运行时动态构建计算图来绕开；具体而言，就是针对给定输入“追踪”前向遍历中遇到的所有运算 [497]。动态计算图（dynamic computation graph）构成 Julia（Tracker.jl、ReverseDiff.jl 或 Autograd.jl）或 Python（PyTorch、TensorFlow Eager、Autograd [JAX]）中许多基于追踪的 AD（tracing-based automatic differentiation）实现的基础。由于实现简单，这种方法在实践中得到广泛采用。这类基于追踪的实现存在一个问题：每条轨迹都依赖于具体取值，这意味着程序的每次运行（使用不同输入）都可能构建一条新轨迹。此外，这些轨迹可能远大于代码本身，例如，循环会被完全展开。

源到源 AD 在源到源 AD（source-to-source automatic differentiation）中，通过生成能够处理所有输入值的反向遍历源代码来克服这些问题 [497]。特别地，分支、循环和递归不会被显式展开。在反向遍历中，通过取回前向遍历所用的中间值来确定正确的分支。事实表明，实现源到源 AD 系统会对底层语言提出许多要求。⁶ Julia 等编程语言使用源到源 AD（Zygote.jl）。⁷

高层伴随规则 反向模式 AD 在机器学习应用中的优势以增加存储需求为代价；在最坏情况下，存储需求与被求值函数中的运算次数成正比。这是因为使用反向模式 AD 时，需要存储前向遍历期间填充的中间变量值，而在前向模式 AD 中，这些值可以直接用于导数计算。如何改善反向模式 AD 实现的存储需求是一个活跃的研究领域。一般而言，可以通过推导高层伴随规则（high-level adjoint rule）来提高反向模式 AD 的效率。例如，考虑程序使用 Newton 法等迭代方法求解非线性问题 $f(\mathbf{x}, \mathbf{p}) = 0$ 的情形。朴素应用反向模式 AD 系统，会产生贯穿所有迭代步骤的反向遍历。这不仅计算代价高昂，还需要存储所有中间迭代步骤的值。与其展开整个计算，不如解析推导适当的伴随规则，再通过一个独立的线性方程在反向模式下计算导数。特别地，它只需要知道非线性问题的最终解 $\mathbf{x}$ ，而不需要中间迭代中的值。更多细节见文献 [460, 239]。还可为常微分方程推导伴随规则 [461, 498, 497, 484]，特征值求解器也是如此 [460]。例如，在常微分方程情形下，伴随规则涉及沿时间反向求解第二个增广常微分方程（augmented ordinary differential equation）。

7.1.2 量子物理问题中的应用

本节通过两个简单例子说明可微编程在量子物理问题中的应用。

逆 Schrödinger 问题 作为逆向设计问题（inverse-design problem）的一个具体例子，我们考虑一维定态 Schrödinger 方程

$$\left[-\frac{1}{2} \frac{d}{dx^2} + V(x) \right] \Psi(x) = E\Psi(x), \quad (7.10)$$

⁶特别是，它应具备强大的内部图结构。

⁷TensorFlow 曾考虑基于 Swift 语言构建源到源 AD。较早的 Fortran AD 系统也是源到源的。




图 7.4: (a) 给定目标波函数 $\Psi(x) = 1 - |x|$ ($|x| < 0.5$), 采用带盒约束的 L-BFGS 算法 (L-BFGS-B) 迭代约 1000 次后得到的优化基态波函数 $\Psi_0(x)$. (b) 优化后的势 $V(x)$ (缩放为原来的 $1/300$) 与初始谐振子势. 图转载自文献 [499].

其中取 $\hbar = m = 1$ [460]. 通常, 我们给定势 $V(x)$, 求解相应的本征函数 Ψ 和能量 E . 这里我们考虑逆问题: 给定一个特定波函数 $\Psi(x)$, 希望构造势 $V(x)$, 使其基态波函数 $\Psi_0(x)$ 与 $\Psi(x)$ 高度吻合. 我们把定义域限制为 $x \in [-1, 1]$, 并定义如下均方误差函数:

$$\mathcal{L} = \int_{-1}^1 |\Psi(x) - \Psi_0(x)|^2 dx. \quad (7.11)$$

势 $V(x)$ 在网格上离散化, 并使用基于梯度的优化方法调节各网格点上的振幅, 以最小化式 7.11. 这一问题的 JAX 实现见文献 [499]. 结果如图 7.4 所示. 这里的梯度由 JAX 底层的 AD 系统计算, 其中需要贯穿本征值求解器传播导数. 关于可微编程在量子力学逆向设计问题中的应用, 以及本征值求解器的伴随方法, 更多细节见文献 [500].

量子最优控制 接下来, 我们考虑一个量子最优控制 (quantum optimal control) 问题. 我们希望找到如下 Hamiltonian 的时间依赖振幅 $\{u_i(t)\}$:

$$\hat{H} = \hat{H}_0 + \sum_{i=1}^{n_{\text{ctrl}}} u_i(t) \hat{H}_i, \quad (7.12)$$

使得 $\hat{H}$ 下的时间演化实现 CNOT 门. 这里, $i \in [1, n_{\text{ctrl}}]$ 的 $\hat{H}_i$ 是时间无关 Hamiltonian, 可以通过时间依赖振幅 $\{u_i(t)\}$ 调节. 我们用 Fourier 级数 $u_i(t) = \sum_{j=1}^{n_{\text{basis}}} u_{ij} \sin(\pi j t / T)$ 参数化这些振幅, 其中引入 n_{basis} 作为使数值求值可行的截断 (cutoff). 为确定给定 $\{u_i(t)\}$ 所实现的量子门, 我们在初始条件 $U(0) = \mathbf{1}$ 下, 从 0 到 T 积分含时 Schrödinger 方程:

$$\frac{dU}{dt} = -i\hat{H}(t)U, \quad (7.13)$$

其中取 $\hbar = 1$. 理想情况下, $U(T)$ 实现 CNOT 操作 ($U_{\text{target}} = \text{CNOT}$). 因而, 我们把损失函数设为

$$\mathcal{L} = 1 - \frac{1}{d} \left| \text{tr}(U(T)^\dagger U_{\text{target}}) \right|, \quad (7.14)$$

其中 d 是相应 Hilbert 空间的维数. 注意, 当 $U(T) = U_{\text{target}}$ 时, 我们达到 $\mathcal{L} = 0$ 的全局最小值. 使用基于梯度的优化方法调节系数 $\{u_{ij}\}$, 以最小化式 7.14 中的损失函数. 这一问题的 JAX 实现见文献 [501]; 其中梯度通过 JAX 中的 AD 计算, 并需要贯穿 ODE 求解器传播导数 (式 7.13). 关于可微编程在量子最优控制中的应用, 更多细节见文献 [478, 132].

展望与开放问题

本节介绍了可微编程这一新型编程范式. 最值得注意的是, 可微编程通过高效、精确且自动地计算相应梯度, 使神经网络训练成为可能 (见节 2.5). 此外, 对任意计算机程序求导的能力, 使神经网络似乎可以纳入科学工作流. 如今, 可微编程在包括量子物理在内的科学计算中已有许多应用. 不过, 该领域仍处于早期阶段, 还有许多开放问题有待解决. 例如, 为量子物理问题所用算法寻找高效的高层伴随规则仍是当前研究课题, 这类算法包括随机动力学 (stochastic dynamics) 求解器 [487]. 另一个例子是混沌系统 (chaotic system); 标准 AD 方法可能在此失效 [502, 503]. AD 系统本身也仍在持续发展: 例如, Enzyme.jl [504] 的思路, 是在 Julia 可移植、低层且与语言无关 (language-agnostic) 的中间表示上执行反向模式 AD. 低层优化由此可以改善性能. 另一方面, NiLang.jl [505] 试图基于可逆编程 (reversible programming) 范式构建反向模式 AD 系统. 在反向遍历中逆向运行程序, 可以避免标准反向模式 AD 的内存开销.

延伸阅读

- Baydin, A. G. 等 (2018), *Automatic differentiation in machine learning: a survey*, *J. Mach. Learn. Res.* 18(1), 5595–5637. 机器学习语境下 AD 的一篇优秀综述 [492].
- Innes, M. 等 (2019), *Differentiable programming system to bridge machine learning and scientific computing*, arXiv:1907.07587. 讨论可微编程在科学计算中的作用 [459].
- Lei Wang 编写的 Google Colab 笔记本 [499, 501].

7.2 多体物理中的生成模型

深度生成模型 (deep generative model) 大多是一类神经网络架构, 旨在逼近我们希望描述的系统或数据集背后的概率密度. 构造给定问题之概率密度的任务通常称为密度估计 [506]. 学得这一底层概率密度后, 便可以从所得密度中采样, 并生成具有该问题特征的人工新样本 (“生成” 模型之名即源于此).

密度估计之所以困难, 是因为在大多数情况下无法精确计算底层概率密度. 对于一大类问题, 这一困难可归因于归一化常数 (即统计力学中的配分函数) 难以计算. 因此, 人们往往必须借助不同方法和技术来逼近底层概率密度函数, 而深度生成模型在其中非常有用.

本书中，读者会遇到量子物理里密度估计任务的多个例子。例如，寻找量子多体系统波函数的（变分）表示，可以视为一项密度估计任务，见章 5。更一般地，在量子物理中，密度估计这一概念常出现于依据量子多体系统上的测量重建多体态的语境；这一任务称为量子态层析，详见节 5.3.7。它尤其具有挑战性，因为实验上只能获得一组受限的量，例如单体密度矩阵或高阶关联函数 [507, 508, 509]。此外，层析实验本身可能非常繁重，单次实验运行就可能耗费很长时间（即数小时或数日）。因而，人们不得不面对如下挑战：依据对一组受限可观测量的相对少量测量，估计高维概率密度。

一般而言，密度估计有两种不同途径：参数密度估计（parametric density estimation）与非参数密度估计（non-parametric density estimation）。在参数方法中，先为近似密度固定一个参数化函数形式。随后调节自由参数，使试探密度尽可能匹配所考虑系统的密度。为此，可以把试探密度同训练数据比较；这些数据对应于从目标密度抽取的观测，也可以把试探密度同未归一化的目标概率密度（例如未归一化的 Boltzmann 分布）比较。参数化试探密度的一个简单例子是 Gaussian 分布，其均值和方差均可相应调节。参数方法把寻找合适密度函数的问题化为寻找合适参数的问题。显然，密度函数形式的选择对这种方法能否成功至关重要，因为它可能显著限制所选 Ansatz 能够有效逼近的目标密度族。

相比之下，在非参数方法中，试探密度函数的结构并非先验设定。⁸ 相反，试探密度函数直接根据训练数据构造。非参数密度估计最简单的例子是构建直方图。显然，直方图分箱存在一些缺点。例如，必须仔细选择箱的大小和位置。此外，直方图是不可微函数。一般而言，与参数方法不同，非参数方法无法利用关于当前系统的先验信息。这虽然使非参数方法稳健且适用于一般问题，却通常也要求大量样本才能达到适当的精度水平。

7.2.1 使用或不使用数据训练

近年来，尤其是在机器学习与物理学的相互作用中，涌现出若干新的密度估计方法。这些方法通常具有参数性质：优化试探密度 q_θ 的一个合适变分（参数化）Ansatz 的参数 θ ，使其匹配目标密度 p 。试探密度 q_θ 有时称为模型。目前先假定它具有一般形式；下一节再讨论 q_θ 的具体参数化。

匹配试探密度与目标密度的一种自然方式基于最大似然估计（MLE）原理：通过最大化似然函数（或等价地最小化负对数似然）来优化参数 θ 。对于由独立观测组成的给定数据集 $\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^n$ ，模型的对数似然函数定义为

$$\ell(\theta | \mathcal{D}) = \log \left[\prod_{i=1}^n q_\theta(\mathbf{x}_i) \right] = \sum_{i=1}^n \log q_\theta(\mathbf{x}_i), \quad \mathbf{x} \in \mathcal{D} \sim p, \quad (7.15)$$

其中， $q_\theta(\mathbf{x})$ 是模型在系统的每个独立观测 $\mathbf{x}$ 处取值的概率密度，而这些观测从待逼近的真实密度 p 中采样。例如，观测集合 $\mathcal{D}$ 可以指狗的图像、从固定温度下 Ising 模型抽取的自旋构型 $\mathbf{x}$ ，也可以指由密度泛函理论计算得到的一组分子构象。随后可以从在其中一种数据集上训练的模型中采样，并分别生成不同的狗图像（具有与训练中所见狗相似的特征）、未见过的 Ising 自旋构型和新的分子构象。

⁸非参数密度估计中的试探密度函数并非完全没有参数，而是其形式不预先固定，即从头学习。

MLE 优化需要训练样本，因此常被称为从数据学习。然而在某些情况下，数据可能并非现成可得，例如生成数据很困难或代价很高。对于这类情形，无法采用上述数据驱动过程。不过，在物理学中，我们有时具备一项优势：知道底层密度的闭式形式，只差一个归一化常数（亦即热力学系统 Boltzmann 分布中的配分函数）。此时，可以采用另一种密度估计途径，有时称为变分推断。这种方法把物理定律和关于物理系统的先验知识编码进参数化密度族 $\{q_\theta\}_\theta$ ，并通过最小化目标密度 p 与变分 Ansatz q_θ 之间所谓的反向 Kullback–Leibler 散度（reverse Kullback–Leibler divergence）[510] 来选取最佳参数：

$$\text{KL}(q_\theta \| p) = \int_{\Omega} q_\theta(\mathbf{x}) \log \frac{q_\theta(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x}, \quad (7.16)$$

其中， Ω 是相关积分域。该量度量目标密度与试探密度之间的差异。⁹ 重要的是，它可以解释为关于模型 q_θ 的期望值，因此其求值只要求能够容易地从 $\{q_\theta\}_\theta$ 中采样。¹⁰ 参数 θ 的这一学习目标也不要求知道 p 的归一化常数，因为它只贡献一个常数平移。我们强调，通过反向 KL 散度进行优化，等价于统计力学中的变分自由能原理 [88, 89]。

如果变分方法优化反向 KL 散度，那么最大似然估计方法等价于优化所谓的正向 Kullback–Leibler 散度（forward Kullback–Leibler divergence）：

$$\text{KL}(p \| q_\theta) = \int_{\Omega} p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q_\theta(\mathbf{x})} d\mathbf{x}. \quad (7.17)$$

事实上，式 7.17 可解释为关于 p 的期望，而先前引入的式 7.15 估计其中依赖参数的项。关于数据驱动方法和无数据方法的总体综述，见文献 [511, 512]。

顺带一提，另一类流行的学习目标是**对抗训练**（adversarial training），我们将在下一节极简要地介绍。不过，它不常用于物理应用，因为它不稳定且需要大量数据。

本节余下内容安排如下：下一节介绍不同的常见深度生成模型类型；最后一节重点介绍一类对物理应用特别有用的模型，即归一化流（NF，节 7.2.3）。

7.2.2 深度生成模型的分类

深度生成模型也称为生成神经采样器（generative neural sampler, GNS），是使用神经网络定义概率分布的机器学习模型。如今它们种类繁多，各有不同性质。我们在节 5.2.1 至节 5.2.2 中已经遇到过受限 Boltzmann 机（RBM）[513] 和自回归神经网络（ARNN）[514]，因此本节只作简要讨论。此外，本节还介绍变分自动编码器（VAE）[515] 和生成对抗网络（generative adversarial network, GAN）[516, 517]。最后，我们将整个下一节专门用于归一化流（NF）[518, 519, 520]。另一类生成模型称为扩散模型（diffusion model）[521, 522]。扩散模型虽然很有前景，但目前在量子科学领域中的应用仍非常有限，因此我们不再进一步讨论。感兴趣的读者可在文献 [522] 中找到全面综述。

在不同类型的生成模型之间做选择，可以反映我们对系统的某些先验知识。例如，我们可以使用 VAE 或 GAN 对能由低维流形表示的密度进行编码。此外，模型容量与其

⁹注意，这一度量可能导致某些病态行为，节 2.3 已经提到这一点。

¹⁰相比之下，最大似然目标要求从 p 中独立同分布地抽样。

可处理性之间通常存在权衡. 这意味着, 表达能力更强的模型往往也更难训练, 因而难以操作. 特别地, 架构的选择决定了模型是否带有直接采样方法, 抑或为生成样本而不得不借助更复杂的 Markov 链 Monte Carlo (MCMC) 采样算法.¹¹ 此外, 在物理应用中, 人们非常希望能够获得可处理密度 (tractable density). 具体而言, 这是应用重加权技术所必需的, 例如神经重要性采样 (neural importance sampling, NIS) [523, 89, 524] 和神经 Markov 链 Monte Carlo (neural Markov chain Monte Carlo, NMCMC) [525, 89, 526]; 我们将在节 7.2.3 中进一步讨论它们.

如果一个模型允许访问可处理密度, 这意味着: 对任意 $\mathbf{x}$, 它都允许以系统尺寸 N 的多项式时间计算已归一化的模型密度 $q_{\theta}(\mathbf{x})$.

基于能量的模型 从历史上看, 基于能量的模型 (例如二元 Boltzmann 机和受限 Boltzmann 机 (RBM)) 是最早提出的一批深度生成模型. 它们深受统计物理启发 (更多细节见节 5.2.1), 因为它们直接参数化概率密度的对数; 这等价于参数化 Boltzmann 分布中的能量. 尽管这些模型很灵活, 形式也十分优雅, 但由于其归一化常数仍不可处理, 它们很难训练. 因此, Boltzmann 机通过近似最大似然原理从数据中学习 [527, 528]. 此外, 由于不存在直接采样方法, 从 RBM 采样不如从其他 GNS 采样高效. 所以, 尽管受限 Boltzmann 机 (RBM) 曾广泛用于量子物理密度估计的早期阶段 [513], 但它们并不总是最适合密度估计的工具.

变分自动编码器 (VAE) 就采样效率而言, 过去十年的发展带来了更复杂的算法, 显著简化了从近似密度中采样构型的过程. 两个主要例子是变分自动编码器 (VAE) 和生成对抗网络 (GAN). 尽管两种算法都令一个低维随机变量通过神经网络, 但 VAE 只追求最大化不可处理似然的一个下界 [79, 80]. 不过, VAE 能够非常高效地抽取新构型.

生成对抗网络 (GAN) 与此不同, GAN 按照所谓的对抗目标 (adversarial objective) 进行训练 [516]. 它们由两个称为生成器 (generator) 和判别器 (discriminator) 的神经网络组成. 生成器学习生成新数据, 而判别器学习区分真实数据与生成数据. 生成器和判别器以对抗方式共同训练, 其中生成器试图欺骗判别器. 这种博弈论式优化策略可能导致非常不稳定的训练过程.

不过, 当训练成功时, 这两个智能体的联合优化会使生成器越来越能够生成非常逼真的样本. 这种方法在实践中效果良好且易于采样, 但遗憾的是, 它不允许访问模型的似然. 因此, GAN 并不是最适合物理应用的模型.

自回归 (AR) 模型 最后, 我们把注意力转向能够访问可处理归一化密度的深度生成模型, 即自回归神经网络 (ARNN) 和归一化流 (NF). 由于下文将会说明的原因, 我们特别强调 NF, 并将整个节 7.2.3 专门用于讨论它们. 现在先讨论 ARNN.

¹¹即使是 MCMC, 其性能也会受到样本间相关性的阻碍 (节 5.2.2 对此有广泛讨论); 在多模态分布的情形下 (概率的不同集中区在构型空间中相距很远), MCMC 甚至可能严重失效.

使用 AR 模型的主要优点是：得益于其闭式似然（closed-form likelihood）以及不相关且快速的采样，可以容易地通过最大似然或变分推断训练它 [529]。样本之所以不相关，是因为概率分布具有 AR 结构；这一结构允许采用直接采样算法，而无须使用 MCMC。节 5.2.2 已经详细介绍了 AR 模型的直接采样，这里提醒读者其过程如下：先从 $q_\theta(\mathbf{x}_1)$ 中采样状态 $\mathbf{x}_1$ ，再从 $q_\theta(\mathbf{x}_2 | \mathbf{x}_1)$ 中采样，如此继续，直至从 $q_\theta(\mathbf{x}_N | \mathbf{x}_{N-1}, \dots, \mathbf{x}_1)$ 中采样。AR 模型能够从指数大的构型空间上的概率分布直接采样（例如当 $\mathbf{x}_i$ 为二元变量时），这使其极为强大。由于可以在一次处理中并行处理许多样本，采样还能进一步加速。注意，把 AR 结构施加于模型会对其形成约束：例如，要构建深层 CNN，就必须引入掩蔽层（以保持 AR 结构），从而改变这类模型的容量。

循环神经网络（RNN） 循环神经网络（RNN）是 AR 模型的一种特殊类型，节 2.4.6 已经介绍过它们。RNN 包含大量模型，例如长短期记忆（LSTM）和门控循环单元（GRU）。后者已用于基态搜索 [266]。在统计力学语境中，RNN 模型还被应用于自旋玻璃等复杂问题。这类模型通常难以采样；因此，直接采样有助于在模拟退火任务中达到很高的精度 [274]。

尽管 AR 模型的关键优势是能够访问可处理的归一化密度，但它们原本仅限于离散随机变量，而且受到相对低效的采样过程影响。也就是说，AR 遵循一种祖先采样（ancestral sampling）方案，其中新样本（例如新图像）按顺序构建；以图像为例，新像素受此前已采样像素的约束 [530]。另一方面，归一化流（NF）同样允许精确的似然密度估计，但更为灵活，能够处理连续随机变量，并允许更快速、更高效的采样。这正是我们在下一节重点讨论这一例子的原因。

最后，我们以几点评论结束本节。这一简短概览表明，对物理应用最值得关注的 GNS 是那些能够直接访问精确（或近似）归一化概率密度的模型。关于深度生成模型的吸引人性质及其物理应用，可参见文献 [89] 中的综述。下面列出其中一些 GNS，并给出它们用于量子物理的相关文献：自回归神经网络（ARNN）[88, 89, 91, 92, 90]、循环神经网络（RNN）[266, 274]，以及变分自动编码器（VAE）[531] 和归一化流（NF）[525, 532, 524] 等潜变量模型。

7.2.3 一个重要示例：归一化流

归一化流（NF）与 AR 模型具有类似的优点，但它们处理连续随机变量，并允许更高效地采样（综述见文献 [520, 519]）。近来已有许多工作成功使用 NF 对格点量子场论中的构型进行采样，其中包括文献 [525, 532, 524]。尽管本节的例子侧重于格点场论的采样方法，但流的应用实际上并不限于这一特定领域。关于深度生成模型在统计物理和化学等领域中应用的更广泛概览，可参见文献 [533]。

归一化流的构造 NF 依赖于一个简单思想：利用坐标变换来重新参数化感兴趣的变量。它们按如下方式生成变量的新实现：首先，从一个已知、可处理的分布（例如正态分布或均匀分布）中采样潜随机变量。随后，该随机变量通过一个在特定约束下学得的双射映射进行变换。也就是说，学习所谓的平凡化映射（trivializing map），使其把基分布的基概率密度变换为一个逼近给定目标密度的密度。如下文所详述，利用变量变




图 7.5: 归一化流 (NF) 架构示意图. 将一系列双射变换组合起来, 便可构造一个复杂的非线性可逆变换, 把概率质量从基分布传输至学得密度. 学得密度可处理且已正确归一化, 因而能够快速、高效地采样. 此外, 借助学得密度还可以生成新样本, 并计算给定构型的精确似然.

换公式, 便可得到目标密度的一个正确归一化且易于处理的变分近似. 换言之, NF 通过学得的双射映射, 把 Gaussian 噪声变换为真实样本.

在 NF 中, 我们定义一个微分同胚¹²的输运映射 (transport map), 它把概率质量从易于处理的基分布重新分配到更复杂的目标密度.

定义潜变量 $z \in \mathbb{R}^D$, 它服从一个已知且易于处理的分布. 常见选择是标准正态分布 $q_z = \mathcal{N}(0_D, I_D) : \mathbb{R}^D \rightarrow \mathbb{R}^D$. 再定义参数化输运映射 f_θ , 它具有如下性质:

- 输运映射 f_θ 是微分同胚.
- 逆映射 f_θ^{-1} 易于计算.
- Jacobian 矩阵 $\nabla_z f_\theta(z) \in \mathbb{R}^{D \times D}$ 的行列式可高效计算.

机器学习文献已经提出许多满足这些要求的候选变换. 其中包括仿射耦合变换 (affine coupling transformation), 例如非线性独立成分估计 (NICE) [534] 和实非保体积变换 (RealNVP) [535], 以及基于卷积的变换 [536] 和基于样条的变换 [537]. 通常, 所需的双射变换由许多这样的简单变换复合而成 (示意见图 7.5); 这些简单变换本身由带有可训练参数集合 θ 的神经网络参数化:

$$f_\theta(z) = (f_{\theta_k} \circ \dots \circ f_{\theta_i} \circ \dots \circ f_{\theta_1})(z), \quad (7.18)$$

¹²若一个函数可微且其逆也可微, 则称该函数为微分同胚 (diffeomorphism).

其中，所有中间变换都可逆、可微，并由各自的参数子集 θ_i 参数化. 关于这些变换的最新综述，我们再次推荐文献 [520, 519].

基密度 q_z 与映射 f_θ 相结合，在该映射把基密度 q_z “推前”时定义了一个新密度 $q_\theta(\mathbf{x})$. 为建立直观认识，我们考察一维问题. 首先注意到，随机变量 $z \in \mathbb{R}$ 的概率质量应在坐标变换 $x = f(z) \in \mathbb{R}$ 下保持不变. 因而可以写成

$$|p_x(x) dx| = |p_z(z) dz|. \quad (7.19)$$

由此得到

$$p_x(x) = p_z(f^{-1}(x)) \left| \frac{dz}{dx} \right| = p_z(f^{-1}(x)) \left| \frac{df(z)}{dz} \right|^{-1}, \quad (7.20)$$

这里使用了双射变换 $x = f(z)$ 及其逆的定义. 更具体地，当双射由 θ 参数化时，有

$$q_\theta(x) = q_z(f_\theta^{-1}(x)) \left| \frac{df_\theta(z)}{dz} \right|^{-1}. \quad (7.21)$$

在上述假设下， f_θ 按构造是可逆的，而 q_z 是我们选作参考密度、用于采样潜噪声 z 的 Gaussian 分布. 对于 D 维问题， $f_\theta: \mathbb{R}^D \rightarrow \mathbb{R}^D$ ，并且式 7.21 中关于 z 的导数要替换为 Jacobian 行列式 $\det(\nabla_z f_\theta(z))$ ；它表示章 7.6 所示的体积变换.

平凡化映射 f_θ 训练完成后，可以在潜空间中采样 $\mathbf{z}^* \sim q_z$ ，再令其通过双射，从而在数据空间中得到相应样本，以生成新数据点 $\mathbf{x}^*$. 反过来，也可以取一个给定样本，将其代入式 7.21，得到该样本的精确似然. 为了使学习和采样过程都顺畅而高效，正如假设中已经指出的，变换的 Jacobian 行列式必须可处理且能高效计算. 关于耦合变换和 Jacobian 计算的更多细节，参见文献 [520].

训练 根据具体应用，可以按照节 7.2.1 所述的方法，使用或不使用数据来训练 NF. 当有来自目标分布 $p(\mathbf{x})$ 的数据集 $\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^n$ 时，可以通过最大化对数似然来训练模型：

$$\log p(\mathcal{D} | \theta) = \sum_{i=1}^n \log q_\theta(\mathbf{x}_i). \quad (7.22)$$

这等价于最小化式 7.17 中的正向 KL 散度.

然而，如前所述，对于物理系统，常见情形是可以得到未归一化的目标密度，却无法轻易获得样本. 在这种情况下，可以改为最小化式 7.16 中的反向 KL 散度来训练 NF. 这种方法不需要数据，因为它通过自采样 (self-sampling) 进行训练；也就是说，在优化过程中，直接从待优化的变分密度 q_θ 中采样构型. 具体而言，给定类 Boltzmann 目标密度 $p(\mathbf{x}) = Z^{-1} \exp\{-H(\mathbf{x})\}$ ，反向 KL 目标可改写为

$$\begin{aligned} \text{KL}(q_\theta \| p) &= \int_{\Omega} q_\theta(\mathbf{x}) \ln \left(\frac{q_\theta(\mathbf{x})}{p(\mathbf{x})} \right) d\mathbf{x} \\ &= \int_{\Omega} q_\theta(\mathbf{x}) (\ln q_\theta(\mathbf{x}) + H(\mathbf{x}) + \log Z) d\mathbf{x}. \end{aligned} \quad (7.23)$$




图 7.6: 变量变换式 7.19 依赖于总概率必须保持不变这一假设. 基密度 p_z 按照 Jacobian 行列式进行变换; 该行列式负责将概率质量重新分配为非平凡的分布. 在一维情形中, 红线标出 p_x 中的概率面积, 并通过双射 f_θ 将其映回基密度 p_z 中的对应面积. 若 Jacobian 行列式为一, 则称该变换是保体积的 (volume-preserving) .

在最后一步中, 我们显式使用了目标密度的已知形式, 其中 $H(\mathbf{x})$ 是 Hamiltonian, Z 是配分函数. 后者此时仅成为一个常数平移; 在优化期间计算梯度时, 它会消失, 因而训练时可以忽略. 利用式 7.21 给出的模型似然解析形式, KL 散度变为

$$\text{KL}(q_\theta \| p) = \int_{\Omega} H(f_\theta(\mathbf{z})) - \log \left| \frac{d f_\theta}{d \mathbf{z}} \right| (\mathbf{z}) + \log q_z(\mathbf{z}). \quad (7.24)$$

不过, 当目标分布是多模态分布时, 按照反向 KL 目标训练模型可能产生不准确的结果. 具体而言, 模型可能完全遗漏一个模态; 这一现象称为模式坍塌 (mode collapse), 我们将在本节的展望部分作简要讨论.

应用 当模型 q_θ 已被训练为目标密度 p 的良好近似后, 就可以使用生成模型 (此处即流) 为物理系统生成近似服从 Boltzmann 分布的构型. 这些由流生成的构型可用于构造物理可观测量的高效 Monte Carlo 估计量. 例如, 可以把 NF 作为提议移动 (proposal move) 纳入 MCMC 采样方案, 以降低自相关并有效进入遍历性区域 (ergodicity regime) (相关工作包括文献 [525, 89, 526]). 这一策略通常称为神经 MCMC 采样 [89] 或 flowMCMC [538]. 在重要性采样方案中, 流也可以作为强大的试探分布 (trial distribution) [523, 539, 89].

基于流的模型还具有一项概念优势; 更一般地, 能够进行精确似然密度估计的生成模型也具有这一优势: 它们允许估计标准方法通常无法获得的量. 这些量包括配分函数

Z、自由能，以及熵和压强等其他热力学可观测量。更多细节见文献 [89, 524, 512]。

关于物理学和量子化学中的更多应用，可参见文献 [540] 的文献综述，以获得更广泛的概览。

展望与开放问题

近年来，NF 展现出巨大潜力和颇具吸引力的概念性质，因而成为处理物理科学中密度估计与采样问题的有前景候选方法。尽管如此，仍有许多挑战需要应对。

首先，基于流的方法有一个主要缺点：它们难以扩展到更大的系统 [541, 542, 543]。迄今利用基于流的采样器取得的有希望结果，特别是在格点场论语境下，都是在相对较小的晶格上获得的。当晶格间距趋于零且体积趋于无穷、从而逼近连续极限时，在尺度扩展方面，标准方法显然会比生成模型更占优势。不过，目前已有一些策略正被探索并得到广泛应用，以改善这些方法的尺度扩展性质。一个例子是利用归纳偏置 (inductive bias)，即利用先验物理知识，把已有对称性纳入流中。这会使训练更加高效，因为模型不必从头学习物理规律。在格点场论的基于流采样器中纳入对称性的思想，已经成功应用于 $U(1)$ [544] 和 $SU(N)$ [545] 格点规范理论。此外，文献 [546, 547] 还从互补角度说明了如何把等变性 (equivariance) 纳入 NF。

前文简要提到的另一项重要挑战，确实与模式坍缩问题有关。这一缺点会影响采用自采样训练的系统，文献 [511, 512, 526] 已经对此展开讨论；它目前不仅是物理学中 NF 领域的开放问题，也是整个机器学习界的开放问题 [548]。学习多模态分布往往更具挑战性，因为容易发生模式坍缩，常常使人无法采用反向 KL 目标。出现这种情况时，生成模型可能完美覆盖目标密度的一个或多个模态，却完全忽略其他模态。因而，从学得的分变分布（例如流）采样时，该分布的支撑集无法完全覆盖目标密度。此时，我们的 Ansatz 对目标的逼近会很差，并导致有偏估计 [549]。在物理学和量子化学应用的采样与密度估计中，经常会遇到这一问题。在某些场景下，模式坍缩可能难以检测；当我们关心可观测量的准确估计时，它因此可能造成严重危害。最近一些工作尝试把 NF 与关于模态的初始知识以及自适应训练方法 (adaptive training method) [526]、路径梯度 (path-gradient) [550, 551] 或退火重要性采样 (annealed importance sampling) [552, 553, 554] 相结合，以解决这一问题。尽管初步结果令人鼓舞，但这仍然是一个远未解决的开放问题。

延伸阅读

- Wang, L. (2018). *Generative models for physicists* [555].
- Noe, F. *et al.* (2019). *Boltzmann generators*. Science, 365, eaaw1147 [523]. Boltzmann 生成器的奠基性论文，讨论 NF 在量子化学中的应用。
- Köhler, J. *et al.* (2020). *Equivariant flows*. arXiv:2006.02425 [546]; Satorras, V. G. *et al.* (2022). *$E(n)$ equivariant normalizing flows*. arXiv:2105.09016 [547]. 介绍如何把等变性纳入 NF。
- Nicoli, K. A. *et al.* (2021). *Machine learning of thermodynamic observables in*

the presence of mode collapse. arXiv:2111.11303 [512]; Hackett, D. *et al.* (2021). *Flow-based sampling for multimodal distributions*. arXiv:2107.00734 [511]; Nicoli, K. A. *et al.* (2023). *Detecting and mitigating mode-collapse for flow-based sampling of lattice field theories*. arXiv:2302.14082 [549]. 进一步讨论模式坍塌问题.

- Albergo, M. S. *et al.* (2021). *Flow-based sampling for fermionic lattice field theories*. Phys. Rev. D, 104, 114507 [556]. 使用 NF 对含费米子的格点场论进行采样.
- Abbott, R. *et al.* (2022). *Aspects of scaling and scalability for flow-based sampling of lattice QCD*. arXiv:2211.07541 [543]. 讨论把 NF 扩展到更大系统时的尺度扩展问题.

7.3 用于实验的机器学习

量子实验带来了严峻的技术挑战；一方面要优化实验性能，另一方面又要解释输出数据，这项任务可能令人望而生畏。值得注意的是，量子器件的输出天然会产生大规模数据，而这正是机器学习大显身手的情形。在章 3 中，我们已经看到如何用机器学习探测物相；虽然处理实验数据时这类工作困难得多，仍有少数研究成功解决了这一现实问题 [140, 557, 106]。在节 4.5 中，我们讨论了 Gaussian 过程和 Bayesian 优化在涉及实验数据的逆问题 [194, 195, 196] 以及实验优化 [205, 206, 207, 197, 214, 215, 216, 217, 218] 中的应用。在节 5.3.7 中，我们还说明了机器学习如何借助章 5 介绍的神经网络量子态来增强量子态层析 [345, 348, 91, 347]。量子实验领域的另一研究方向，是把强化学习用于量子反馈控制 [421, 422, 423, 424]、量子纠错 [432, 433, 431, 434]、量子电路优化 [426] 和实验设计 [375]；这些内容均已在节 6.6.3 至节 6.6.6 中介绍。

本节关注处理实验数据的其他机器学习方法。首先，我们指出，实验物理学中有一个可能被机器学习彻底改变的重要领域，即对繁琐重复任务的实验自动化（experimental automation）。我们将在节 7.3.1 中展示这一思想结合真实实验数据的成功实例。在节 7.3.2 中，我们讨论基于机器学习分析飞行时间图像（time-of-flight image）的理论方案；飞行时间成像是超冷原子装置中的一种标准测量技术。随后，我们在节 7.3.3 中介绍一种用于量子实验的强大方案，即从测量中学习支配系统的 Hamiltonian。最后，节 7.3.4 讨论不采用强化学习的计算机辅助实验设计所取得的成功。

7.3.1 实验装置自动化

本节介绍物理实验自动化的新思路。具体而言，我们将介绍面向量子器件技术的纳米材料样品自动识别 [558]，以及面向量子信息器件的双量子点自动调谐 [559]。

这两个例子有一个共同点：在各自实验的某个执行阶段，都需要投入大量人力。就操作人员所采用的决策过程而言，这类工作繁琐而重复，却又没有简单到可以用普通循环算法替代。

纳米材料的自动识别 如文献 [558] 所详述，在制备用于量子器件的纳米材料时，一个重要步骤是在显微镜下从晶片中选出合适的二维薄片。这些薄片会因其在最终器件




图 7.7: 实验纳米薄片装置. (a) 文献 [558] 中的典型 hBN 显微镜图像. (b) 已将晶片置于显微镜下的典型显微镜装置. 图片来源: ETH Zürich Klaus Ensslin 实验室.

中的预期用途而有所不同, 但由于预先采用的剥离制备技术, 它们都具有扁平形状和近似的尺寸. 例子包括六方氮化硼 (hBN)、石墨和双层 graphene. 图 7.7 展示了扫描装置以及一幅典型的 hBN 图像.

典型装置中的显微镜可以在不同放大倍数下工作, 并能在约三分钟内扫描面积为 1 cm^2 的晶片. 然而在实践中, 这一过程耗时长得多, 因为操作人员必须缓慢地在晶片上移动视野, 并逐帧判断图中哪些薄片适合以后制造器件. 简言之, 操作人员是在对薄片进行分类; 训练良好的神经网络同样可以完成这项工作. 因而, 设计并训练合适的神经网络架构, 是文献 [558] 所提出自动化方案的核心.

不过, 值得注意的是, 如图 7.8 所概括的那样, 这一自动化方案所做的不只是分类任务. 例如, 在实现任何与网络有关的部分之前, 研究人员先为实验团队提供了一个带简单 GUI 的程序, 用于通过点击给预处理图像中的薄片加标签, 从而简化充足数据集的生成. 在此特别说明这一点, 是为了如实反映使用实验装置时还必须考虑的额外步骤.

为尽量减少分类错误, 这项工作使用了不止一个网络: 三个网络依次应用, 每个网络都由四个 convolutional 层和一个 dense 层组成. 之所以需要堆叠这些网络, 是因为数据集中优质薄片与劣质薄片的比例极不平衡. 批量优化结合数据增强 (data augmentation) 通常可以在一定程度上处理这种不平衡, 但在这里仍不够: 把一组约含 1000 个薄片、其中 10.8% 为优质薄片的新数据输入单个已训练网络后, 分类结果的准确率为 86%, 其中有 13% 的假阳性 (false positive) (把劣质薄片错误判为优质) 和 1% 的假阴性 (false negative) (把优质薄片错误判为劣质). 由于真正优质的薄片很少, 避免假阴性至关重要.

分类结果中剩余“优质”薄片 (无论分类正确与否) 的数量与准确率, 还有一个重要而更实际的方面, 即分类后需要投入的额外人力: 分类完成后, 自动化方案 (参见图 7.8) 会自动放大优质薄片, 之后再由操作人员介入. 更具体地说, 在人工方案中, 操作人员要手动扫描样品, 查看例如现有的 1000 个薄片, 放大选中的薄片, 再判断其是否优质; 而在自动化方案中, 只有当整片晶片扫描完毕, 且显微镜已移动到各个优质薄片的位置并适当放大之后, 操作人员才开始工作.

这样, 实验人员只需最终决定使用哪些薄片; 需要检查的薄片数从 944 个大幅降至




图 7.8: 完整的自动化流程包括扫描、标注、预处理、训练、分类, 随后收集并呈现优质薄片. 斜体标出的步骤只在实际应用之前执行. 图片来源: [QMAI 团队](#), [TU Delft](#).

224 个, 其中约 44% 确实是优质薄片. 不过, 由于仍需人工检查, 研究人员使用三个网络而不是一个, 以进一步减少必须查看的薄片数. 数据依次通过三个网络后, 只需查看 150 个薄片, 其中约 57% 为优质薄片.

准确率仍相对较低的原因之一, 是预先执行标注的人员在分类选择上存在差异. 即使借助为此编写的 GUI 程序, 标注足够大的数据集也已经非常耗时, 因此每个薄片只由参与项目的多名实验人员之一标注一次. 图 7.9 呈现了三名参与者查看一组单次拍摄图像帧时的判断差异. 需要强调的是, 这里我们能够明确展示数据制备中不确定性和误差的一个来源, 但通常无法直接看到它; 因此必须始终承认它们可能存在.




图 7.9: 人类判断差异的可视化. 选取 15 个待判断是否含有优质薄片的图像帧, 并给出三名不同操作人员的判断结果. 改编自文献 [558].

显然，对于各图像帧是否含有优质薄片，人们的判断存在一定程度的不确定性和分歧，这给模型性能设定了上限。分类准确率反映了这一点。

总而言之，所开发的、包含并围绕神经网络构建的自动化流程仍然显然是成功的：这类材料筛选是纳米材料器件开发领域的常见步骤，而且该方法也能令人满意地推广到石墨、双层 graphene 等材料（参见文献 [558]）。实现代码可在 GitHub 获取 [560]。

量子点调谐 下一个例子是量子信息技术研究中双量子点的自动调谐，详见文献 [559]。量子点（quantum dot）是一种在三个空间维度上都受到极强约束、因而实质上为零维的纳米结构。这种约束类似于箱中粒子情形，会产生量子效应，即能量量子化（而较大结构具有连续能谱），从而形成离散态。

在量子信息研究中，把两个量子点组合为离散态即可构造 qubit。这项技术用于通用量子计算时面临多种挑战：一方面，难以让两个量子点以可控方式相互作用；另一方面，还存在可重复性问题。两者都与制备技术有关，而这里讨论的例子为前一问题提供了一种新的机器学习解决方案。

与上一例相同，实验流程中也包含一个可以尝试自动化的繁琐步骤。薄片例中，操作人员查看显微镜下探针获得的图像；而在该量子点装置中，操作人员查看改变外加电压时，量子器件内电流测量变化所生成的图。这类测量关心的量是量子点的占据，即量子点的状态。对量子点施加电压可以改变其占据：如图 7.10(a) 所示，三个量子点各自配有用于调节电压的柱塞栅（PG）。在这些量子点下方，测量一个量子点接触（quantum point contact）的电流。¹³ 根据 Coulomb 定律，量子点的占据，即相应电子的负电荷，会影响邻近电流。因而，电子占据改变会使电流发生离散变化，对应于电导测量 $\partial I_{\text{QPC}}/\partial V_{\text{PG}}$ 中的尖峰。这些尖峰就是图 7.10(b) 所示电荷稳定性图（charge-stability diagram）中的深蓝色线。图 7.10(b) 可解释如下：左下角的两个量子点均未被占据；每跨过一条竖直（水平）线，就会向 QD1（QD2）加入一个电子。

器件制备和调谐的目标，是施加适当电压，以制备不同的离散态；这些电压对应于电荷稳定性图中由正确电流尖峰线围成的菱形区域。为此，操作人员需要知道电荷稳定性图。因而，调谐这样的双量子点器件需要测量完整电荷稳定性图，即连续执行许多次测量，其中一个电压保持不变，另一个逐渐改变。在这种极其耗时的情形下，基于分类的机器学习方案可以提供帮助。

要让机器学习带来显著改进，关键是输入数据不再需要测量完整电荷稳定性图。合适的方案应当能够从任意初态（对应一对初始电压及其电流）出发，给出指定期望占据态所需的两个柱塞栅电压。然而，没有电荷稳定性图，就无法知道两个初始电压对应哪一种占据态。例如，若初态的两个电压均为 0 V，了解图 7.10(b) 的操作人员会知道该状态位于图的右上部，并可通过数线确定其状态。

为了避免测量整张图，机器学习方案采用只需电荷稳定性图中低分辨率小区域的方法：

1. **寻找 (0, 0) 态**：第一步利用如下事实：除 (0, 0) 态外，任意状态在图中都由四条线围成，而 (0, 0) 态只在正 x 和正 y 方向有相邻线。因此，训练第一个分类网络，识别负 x 或负 y 方向是否还有需要跨越的线；输出为真或假。若仍有线，就把两个

¹³图 7.10(a) 中的量子点接触由底部负责测量的三个栅极形成。




图 7.10: 量子点实验装置. 器件制成后, 利用其中量子点接触所实现的测量进行调谐. (a) 示例器件的扫描显微镜图像. 基底材料是 GaAs 异质结构; 在计划设置三个量子点 (QD1、QD2、QD3) 的位置嵌有电子气. 图中还有多个用于约束和测量的指状栅极; 负责测量的是底部构成量子点接触的三个栅极. (b) 使用 (a) 中 QD1 和 QD2 的双量子点器件之电荷稳定性图. 相应改变的是 PG1 (对应 QD1) 和 PG2 (对应 QD2) 的电压. 引自文献 [559].

柱塞栅电压降低一个固定量 (如图 7.11(a) 所示), 随后再次分类, 直到不再有线需要跨越.

2. **寻找任意给定的期望态:** 要从 (0,0) 态到达任意期望态 (m,n), 必须恰好跨过 m 条竖线和 n 条横线. 因此, 训练第二个网络, 更准确地区分存在哪些线. 该网络使用分辨率更高、范围更小的视窗, 从而区分所考察视窗中无线、仅有一条竖线、仅有一条横线以及两者均有这四种情形 (参见图 7.11(b)). 与第一步一样, 每次分类后都改变电压, 并重复这一两步流程, 直至达到期望态.

训练第一个网络时, 以较低分辨率测量了 470 张电荷稳定性图; 训练第二个网络时, 则以较高分辨率测量了 128 张. 不同测量采用不同的柱塞栅电压范围, 以促进后续泛化. 两种情况下, 数据集都是从图中随机裁出大量视窗, 再由脚本加标签得到的. 注意, 虽然为了生成训练数据集而测量了完整电荷稳定性图, 但网络最终应用时的输入只需小视窗. 测量完整电荷稳定性图并利用其中大量视窗, 只是创建数据集的一种便利方式.

在实际器件上测试时, 两个循环的成功率分别为 90% (步骤 1) 和 63% (步骤 2), 合并后的总体成功率为 57%. 必须注意, 这些单项成功率并不等同于两个网络的准确率: 每个循环会多次调用网络, 误差必然累积; 而第二个循环的视窗更小, 通常比第一个循环调用网络更多, 见图 7.11(a)、(b). 事实上, 在带标签数据集上分别只测试一次时, 两个网络的准确率达到 98.9% 和 96%. 作者指出, 主要误差源是信噪比较低; 改善信噪比无疑会提升该方案.

总之, 把深度神经网络集成到更大方案中可能导致误差累积, 规划自动化流程的实现时必须考虑这一点. 一般而言, 把机器学习方法集成到更广泛的自动化方案中, 对网络准确率有不同层次的要求; 如第一个例子所示, 有些情形甚至会从根本上限制网络准




图 7.11: (a) 用第一个分类网络寻找 $(0,0)$ 态: 随机初始电压对应点“1”. 本例中, 网络经过三轮分类和视窗移动, 最终到达标为“3”的 $(0,0)$ 态. (b) 寻找期望占据 (m,n) : 根据不同分类结果, 视窗可以只向更高 PG1 电压移动 (存在一条竖线)、只向更高 PG2 电压移动 (存在一条横线), 或沿对角线移动、同时提高两个栅压 (存在两条线). 改编自文献 [559].

确率. 实现之前必须考虑这些因素, 并权衡自动化的收益与剩余工作量.

当然, 上述方法并非实验装置自动化的全部思路. 例如, 卷积神经网络还能用于检测大分子衍射数据中的冰晶衍射污染 [561], 或分析蛋白质的冷冻电子显微镜图 [562].

7.3.2 飞行时间图像的机器学习分析

在实验数据分析方面, 我们再介绍一个与超冷原子实验有关的例子. 与节 7.3.1 中已经讨论的两个高度专门化、直接使用真实实验数据的应用不同, 这里考察的是一项基于理论数据、但很容易推广到实验的方案 [563]. 目前正在发表许多立足理论但面向应用的方案, 讨论它们之间的差异很有启发性. 我们关注的是从理论过渡到应用是否可行.

机器学习范围内的任何这类理论到实验的过渡, 都应考察以下方面:

- **方法的专用性与灵活性:** 正如前两个例子所讨论的, 当机器学习模型没有为模型物理提供真正的新见解时, 自动化就应显著减少人力投入. 可以针对某个工作量很大的单一场景设计专门方案, 也可以针对大量工作量中等的场景设计灵活方案, 以实现这一目标.
- **理论结果与实验结果的相似性:** 理论模型产生的结果往往与相应实验结果有显著差异, 这可能源于实验噪声或理论模型的局限. 对仅以理论结果训练的模型, 必须评估进一步的预处理 (例如加入人工噪声) 是否足以使网络架构能够接收实验数据, 以及网络需要多大程度的重新训练.

量子点和薄片工作采用的是影响显著的专门方案, 而这里提出的方案非常通用, 并利用了所探测系统——超冷原子——的灵活性. 这类装置具有很高的可控性, 因而超冷原子是模拟从少体到多体的众多物理现象的典范量子模拟器. 值得注意的是, 无论所研究的实验效应是从 superfluid 态到 Mott-insulating 态的动力学转变、通过量子点接触




图 7.12: 把机器学习用于从超冷原子测量中提取可观测量: 传统实验方法通常只能通过平均方法提取一阶和二阶密度矩阵; 机器学习方法还可以从动量空间测量中提取实空间可观测量及关联函数. 引自文献 [563].

的电导量子化, 还是双阱势中 condensed 态与 fragmented 态的多体性质, 实验的标准输出都很相似, 即飞行时间图像.

在实验装置中, 让最初受俘获的超冷原子云自由膨胀, 再用飞行时间成像获取原子云快照. 这些单次拍摄图像 (single-shot image) 携带大量信息, 因为它们可以无歧义地联系到众多物理量和物相. 实验人员通常只能通过平均技术提取少量可观测量, 但研究表明, 机器学习工具应能更准确地利用数据所含信息, 并获取范围更广的可观测量 (参见图 7.12). 作者提出的基于人工神经网络的方法利用不同拍摄之间的涨落, 隐式重建多体态. 这为实验中的广泛应用带来了希望.

比较理论预测与实验结果时, 噪声成为重要因素. 对超冷原子, Lode *et al.* (图 7.12) 提出了一种从超冷原子单次拍摄图像中优化读取可观测量的方法. 他们认为, 理论模拟




图 7.13: 一个系统从 superfluid self-organized phase (State 1) 转变到 superfluid Mott insulating phase (State 6) 时, 实验测得 (上排) 与模拟得到 (下排) 的动量空间密度分布之比较. 改编自文献 [564], 采用 CC BY 4.0 DEED 许可.

和实验探测到的单次拍摄图像足够相似，因此在训练时向理论数据加入人工 Gaussian 噪声应当足够。

图 7.13 比较了光学腔中随某一外部激光强度增加而发生相变时，不同相变阶段超冷原子的模拟与实验单次拍摄图像。虽然该例来自不同框架，但两篇论文生成单次拍摄图像时使用了相同的模拟方法 [564, 565]。噪声明显存在，但相变各阶段的符合程度令人满意。

除了向理论数据加入人工噪声，还可以尝试从实验数据中减去噪声，例如使用去噪自动编码器。最终选择哪种方案，自然取决于给定的实验和理论数据。对单次拍摄图像而言，去噪方法可能并不理想，因为多体系统固有的量子噪声 (quantum noise) 很难与其他噪声源区分，因而难以选择性去除。

总的来说，我们已经看到，机器学习技术可以帮助弥合理论模型与受噪声或资源限制的实验实现及测量之间的鸿沟。这些结果奠定了坚实基础，表明机器学习能够增强实验量子物理学，并指出未来几年机器学习与量子领域融合的有前景方向。

7.3.3 Hamiltonian 学习

本节关注如何验证俘获离子、Rydberg 原子、超导量子比特或光晶格中的超冷原子等量子模拟器 [566, 567, 568, 569]。¹⁴ 这些实验装置已得到充分理解，可用来模拟由相同 Hamiltonian 支配、但更复杂且更具挑战性的系统。我们正进入一个令人振奋的时代：量子模拟器开始变得非常复杂，尤其是已经无法用经典计算机求解。例如，处理含 50 个量子比特的量子模拟器时，必须面对量级为 10^{15} 的巨大 Hilbert 空间。那么，如果无法用经典计算机验证结果，我们如何知道这些模拟器是否按预期工作？这个问题的一种可能解决方案称为 Hamiltonian 学习 (Hamiltonian learning)，也是本节的主题。这里特别讨论文献 [570] 提出的方法。

Hamiltonian 学习的核心思想，是重建从实验可访问的测量结果到底层 Hamiltonian 参数的映射。

本节讨论的方法利用神经网络提取支配所构造量子模拟器的参数。一个示例流程如下：先进行数值模拟，针对参数已知的相应 Hamiltonian 生成实验可访问的数据（例如实空间图像）；再通过监督学习训练神经网络，使其预测这些 Hamiltonian 的参数；最后可用实验量子模拟器产生的测量结果测试网络，而实验中的底层 Hamiltonian 并不完全已知。也可以反转这一流程：给定量子系统 Hamiltonian 的定义参数，用神经网络高效学习系统的相关特征 [571]。

用神经网络说明 Hamiltonian 学习过程的一个非常简单的例子，是图 7.14 所示的单自旋系统。首先，制备已知 Hamiltonian $\hat{H}_0$ 的初态；这里取 σ_z 的本征态（自旋“向上”）。其次，在未知 Hamiltonian $\hat{H}_1$ 下作么正演化，使自旋绕 Bloch 球的一条轴进动。让系统演化一段时间 t_m 后进行测量。多次重复制备初态和演化的过程（演化时间 t_m 也可能不同），从而收集测量数据集。现在希望从这些测量中学习未知的 $\hat{H}_1$ ，也就是自旋绕球面的进动速率。在此例中，需要一系列测量才能得到振荡频率 ω 。这一流程可以推

¹⁴对于特定的量子模拟问题和 Hamiltonian，不同实验装置各有优缺点。量子模拟与量子计算的一个区别是：量子模拟器是针对特定问题设计的，而量子计算更为通用，能够求解一般问题。




图 7.14: 单自旋系统 Hamiltonian 学习流程示意图. 将自旋制备到一个初态, 使其在未知 Hamiltonian 驱动下演化一段时间 t_m , 随后测量系统. 多次重复该过程 (演化时间 t_m 也可能不同), 收集测量数据集, 并由此学习旋转频率.

广到任意已知初始 Hamiltonian $\hat{H}_0$ 和驱动系统么正演化的未知 Hamiltonian $\hat{H}_1$.

下面关注另一种量子模拟器实验装置: 处于谐势中的中性原子, 系统包含 2×50 个格点. 该系统的初态由光晶格中原子的位置给出, 实验装置可由 Bose-Hubbard Hamiltonian 描述:

$$\hat{H}_{\text{BH}} = - \sum_{\langle i,j \rangle} J_{ij} \hat{a}_i^\dagger \hat{a}_j + \sum_i \frac{U_i}{2} \hat{a}_i^\dagger \hat{a}_i (\hat{a}_i^\dagger \hat{a}_i - 1) - \sum_i \mu_i \hat{a}_i^\dagger \hat{a}_i. \quad (7.25)$$

其中, J_{ij} 描述格点 i 与 j 之间的跃迁, U_i 是在位能, μ_i 是光晶格中原子的化学势. 即使只考虑该晶格中的 10 个粒子, 相应 Hilbert 空间的维数也达到 10^{13} , 并有 350 个参数需要估计. 这带来两个主要问题: 第一, 波函数过大, 无法模拟该系统; 第二, 需要求解一个 350 维优化问题. 因此, 先考虑图 7.15(a) 所示、由 4 个原子构成的小系统, 它把参数数目降至 25, 将 Hilbert 空间维数降至 330. 这样消除了 Hilbert 空间过大的问题, 只留下优化问题.

现在希望建立从测量结果到式 7.25 中 Hamiltonian 参数的映射.¹⁵ 为此, 使用监督学习训练神经网络并进行回归. 这种设置的挑战是训练数据随输出规模的标度关系. 若用单个神经网络预测全部参数, 如图 7.15(b) 所示, 就需要为 25 个参数的所有组合提供多个样例; 由于所需训练集极其庞大, 这对大多数应用并不可行. 解决方案很简单: 不用一个神经网络预测全部参数, 而是训练 25 个神经网络, 通过连续回归分别预测各个参数.

此外, 实验快照未必是数据集的最佳表示. 一种更有效的表示, 是从实验快照批次转向特定 Hamiltonian 的关联函数. 本例使用密度关联函数, 它通过降低输入维数, 使神经网络的训练高效得多, 如图 7.15(d) 所示. 成功训练后, 神经网络利用 2500 张快照

¹⁵这里以精确模拟作为“测量”, 而没有使用实验快照; 输入图像是光晶格中原子的实空间位置.




图 7.15: (a) 含 4 个原子和 25 个参数的系统示意图. (b) 利用一个神经网络和监督学习, 建立从实验快照到 Hamiltonian 参数的映射. (c) 用“墙”把晶格“划分”为多个子系统, 从而推广到更大的系统尺寸. (d) 建立测量结果到参数映射的一种更高效方式. 改编自文献 [570]. 补充图片来源: QMAI 研究组, TU Delft.

预测实验参数时, 误差率约为 0.1%. 以 Bayesian 推断为基准, 在 2500 张快照的小数据集上, 神经网络方法优于 Bayesian 结果; 但在约 20 000 个样本的大数据集上, 两种方法预测参数的准确率相同.

到目前为止, 我们只考虑了可由经典计算机求解的 4 原子小系统. 下面介绍一种把该特定 Hamiltonian 推广到更大系统尺寸的方案. 在这一实验装置中, 可以调制晶格并建立墙, 把含 50 个格点的链分成若干四格点单元 (见图 7.15(c)). 该系统的 Hamiltonian 参数是局域的, 只需学习 $\hat{H}$ 中不受边界影响的项; 它们称为“有效参数” (见图 7.16). 接着, 每次把边界移动一个格点, 并在每个位置测量 2500 次. 当系统一直移动到达到平移不变性的程度时, 所有参数都至少在一种构型中不受边界墙影响, 并由神经网络成功学得.

如上所述, 这一流程对该系统具有很强的专用性, 难以推广到其他系统. Hamiltonian 学习领域仍处于早期阶段, 适用于大系统和复杂 Hamiltonian 的通用方案尚待开发 [572]. 不过, 对于验证量子模拟器是否正确工作这一重要任务, 它是一种很有前景的方法; 随着量子模拟器的规模和适用性不断增长, 并可能超越经典计算能力, 这种验证会变得越来越重要.

7.3.4 实验的自动化设计

在面向实验提出的机器学习应用中, 我们已经讨论了如何用神经网络加速、优化和验证实验装置, 以及分析所生成的数据. 另一项应用是由人工智能引导的实验设计, 它或许有一天会彻底改变科学.




图 7.16: 针对该特定系统和 Hamiltonian, 从 4 个格点标度到 50 个格点的方案. 对四种墙构型中的每一种都采集 2500 张快照, 用于训练神经网络并学习全部参数. 改编自文献 [570].




图 7.17: 一种称为 MELVIN 的计算机启发量子光学实验算法示例. 改编自文献 [438].

在新实验的设计方面, 迄今大多数工作集中于量子光学 [436, 375, 438, 437, 573, 574]. 设计这类实验, 就是组合分束器、反射镜和晶体等不同光学实验室元件, 使最终量子态具有特定的期望性质. 例如, 我们可能希望获得具有高维多体纠缠 (即多个粒子之间的纠缠) 的量子态; 这种纠缠对量子信息与计算应用极为重要 [435]. 受过训练的物理学家固然能够设计出产生具有非平凡性质量子态的实验装置, 但这项任务可能非常困难, 而且严重依赖反复试错.

在节 6.6.6 中, 我们已经介绍了一个用强化学习自主构建量子光学实验的例子 [375]; 它采用了我们在节 6.5 中介绍的投影模拟算法. 有趣的是, 还有另一种由人工智能引导的光学实验设计方法, 已经促成世界各地多个实验室中的十余项新实验 [438]. 所提出的算法称为 MELVIN [436], 如图 7.17 所示.

要应用 MELVIN, 用户需要指定一个工具箱, 即一组可用的光学实验室元件. 此外,

用户还要定义目标性质，以及刻画最终量子态的所有可能条件。MELVIN 算法先随机排列可用光学元件，生成一个实验装置。每个光学元件都对应输入态的一种已知符号变换。由于初始量子态以及施加于它的符号变换均已知，随后便可计算所得量子态及其性质。如果量子态满足全部判据并呈现目标性质，MELVIN 就向用户报告该装置。¹⁶ 更常见的情况是，生成的量子态与目标态不匹配，于是 MELVIN 重新生成另一个装置。因此，MELVIN 在很大程度上基于随机搜索。

不过，与完全随机搜索相比，MELVIN 有两个特征可带来显著加速。第一，如图 7.17 所示，用户可以把所需判据划分为计算代价低和计算代价高的两类；只有先满足代价低的判据，才计算代价高的判据。第二，MELVIN 可以把已经测试过的构型加入初始工具箱，并在后续尝试中把它们用作基本构件，从而扩展工具集。这种可用工具的扩展可视为 MELVIN 的一个学习成分。

例如，MELVIN 已用于寻找生成上述高维多体纠缠态的实验装置。在文献 [436] 中，MELVIN 找到了产生不同纠缠方式量子态的装置。特别地，它发现了第一个能够在实验中实现、可产生所谓高维 Greenberger–Horne–Zeilinger 态的方案 [436]。此外，正如文献 [436] 的作者所承认，所得实验包含一些他们此前并不知道、颇有意思的新实验技术。

最后，对 MELVIN 的研究表明，每种光学装置和初态都可表示为加权图。MELVIN 的后继算法称为 THESEUS [437]；它利用图表示，以基于梯度的最优权重搜索取代随机搜索。THESEUS 的发现速度不仅比 MELVIN 快几个数量级，而且只要表示所发现实验装置的图足够小，它还能给出可解释的解。

展望与开放问题

总结节 7.3，机器学习可以用于加速、优化、验证和设计实验，也可以分析所收集的数据。用机器学习加速和优化实验工作的设想最早可追溯到 2009 年 [575]；这或许解释了为什么此类应用是机器学习在实验物理学中最受广泛认可的作用之一。一个引人入胜的方向是所谓的自主实验室（self-driving laboratory）[576]：它把自动化实验平台与人工智能方法相结合，实现自主实验。这种实验室有望加快发现速度，并把实验人员从繁琐任务中解放出来。

对于现代量子技术，核心挑战是高效表征量子系统、验证量子器件，以及检验作为基础的物理模型。人们期待机器学习降低这些任务的计算成本。因此，基于机器学习的 Hamiltonian 学习正成为验证量子实验的一项常用技术。有趣的例子包括它在氮空位中心（nitrogen-vacancy center）装置 [577] 和核磁共振测量 [578] 中的应用。

把机器学习方法标度到更大尺寸的量子器件，仍是一项重要挑战。虽然机器学习算法在大型实验数据集上表现出色，但增加量子比特数目（从而增加调谐参数）会造成学习困难。这些问题在量子点系统中尤其棘手。目前已有同时调谐多个参数 [579, 580] 或减少调谐所需实验数据量 [581] 的尝试。然而，要高效调谐包含数百个参数的大规模量子器件，仍需新的方法。

此外，人工智能有望在新实验设计方面带来突破。特别地，有观点认为，当人工智能不了解人类已有方法时，它能够给出跳出常规思路的解 [436, 438, 582]。迄今，由人

¹⁶报告解答之前，还可以选择使用用户预先定义的确定性方法简化装置。例如，可迭代地随机移除一个光学元件，并检查最终量子态是否发生改变。

工智能引导的设计主要在量子光学中得到探索，并取得显著成功。不过，所讨论的方法（MELVIN 和 THESEUS）只能直接推广到这样一些实验：我们能够计算装置的每项改动如何影响所生成的量子系统及其期望性质。若实验的理论描述计算代价极高（或根本不存在），把 MELVIN 或 THESEUS 应用于这些实验就需要新思路。由人工智能引导发现实验装置的另一个例子，是利用基于图的搜索，根据光谱数据自动识别分子的激光冷却方案 [582]。该方法通过扩展可用超冷物种的范围，有望推动超冷化学和物理学取得突破。这种自动搜索之所以再次成为可能，是因为激光冷却背后的物理已经得到充分理解。

最后，把自主实验室的设想与由人工智能设计新实验结合起来，颇具启发性：这将创造一种终极机器人科学家，它永不疲倦，也永不停止寻找新的解答与发现。

延伸阅读

- King, R. D. *et al.* (2009). *The automation of science*. Science, 324, 85–89. 该文报道了最早的一批“机器人科学家”之一 Adam 的构建，其目标是自动形成假设并记录实验 [575].
- Wiebe, N. *et al.* (2014). *Hamiltonian learning and certification using quantum resources*. Phys. Rev. Lett. **112**, 190501. 首次提出把量子模拟器与 Bayesian 推断相结合的 Hamiltonian 学习方案 [583].
- Raccuglia, P. *et al.* (2016). *Machine-learning-assisted materials discovery using failed experiments*. Nature 533, 73–76. 一个利用机器学习发现材料并优于传统人工方法的例子 [584].
- Häse, F., Roch, L. M., & Aspuru-Guzik, A. (2019). *Next-generation experimentation with self-driving laboratories*. Trends Chem. 1, 282–291. 关于自主实验室及其在科学发现中作用的展望 [576].

用于深度学习的物理学




图 8.1: 机器学习与物理学之间存在双向影响. 本章关注较少为人所知的方向, 即物理学用于机器学习.

到目前为止, 我们讨论了机器学习旨在解决量子科学中各种问题的不同应用. 与之相对, 本章关注物理学 (尤其是统计物理学和量子物理学) 如何影响机器学习研究, 如图 8.1 所示. 在节 8.1 中, 我们解释机器学习面临的基本理论挑战, 并展示统计物理学工具如何帮助阐明这些问题. 在节 8.2 中, 我们讨论量子计算以及量子机器学习的前景.

8.1 机器学习的统计物理学

本节介绍如何应用物理学概念——尤其是热力学极限或描述相变的序参量等统计物理学工具——发展机器学习理论 (见图 8.2) [585]. 这一思想早在 20 世纪 80 年代便




图 8.2: 用于理解机器学习理论的统计物理学工具箱.




图 8.3: 对泛化的经典理解与现代理解. (a) 经典的 U 形误差曲线源于偏差-方差权衡. (b) 双下降误差曲线既包含经典区域中的经典 U 形曲线, 也包含现代过参数化模型的低泛化误差. 改编自文献 [63].

已诞生, 而 21 世纪 10 年代的深度学习革命使人们重新对这种方法产生浓厚兴趣.

统计物理学的帮助确实十分必要, 因为机器学习中的许多难题仍未得到理解. 例如, 现代神经网络可以拥有数十亿个可训练参数.¹ 在如此巨大且非凸的损失景观中, 我们究竟如何找到泛化良好的极小值? 另一个谜题与所谓的偏差-方差权衡有关; 我们已在节 2.2 中展示过这一权衡. 它表明, 在模型复杂度很高的区域, 模型应当像图 8.3(a) 所示那样严重过拟合数据集. 但在实践中, 这些巨大的过参数化深度学习模型却像图 8.3(b) 所示那样具有很好的泛化能力. 那么, 它们如何摆脱传统的偏差-方差权衡? 一个相关问题是深度学习模型的容量, 以及如何发展有用的容量度量. 要全面理解这些谜题, 我们还有很长的路要走. 一种处理方式是遵循物理学家研究新系统的传统方法, 考察简单且可解的模型. 玩具问题的结果可以为更复杂模型的工作机制提供线索.

本节分为四部分. 首先, 在节 8.1.1 中, 我们回顾关于感知机容量的奠基性研究, 由此说明统计物理学如何帮助研究学习问题. 随后讨论这一交叉研究的三个方向: 在节 8.1.2 中以教师-学生范式 (teacher-student paradigm) 研究泛化; 在节 8.1.3 中讨论如何建模数据结构; 以及在节 8.1.4 中研究学习动力学.

8.1.1 感知机的容量

我们能想到的最简单机器学习模型, 是已在节 2.4.4 (见图 2.6(b)) 介绍过的单个感知机 f . 本节关注它的容量, 即它能拟合多少个数据点. 为回答这个问题, 我们进一步假设数据集处于一般位置 (general position).² 这一假设是合理的——如果同一个训练点有许多副本, 它们不应当影响模型容量的估计.

单个感知机只能学习线性可分模式. 因此, 容量问题可以改写为: 带二元标签、大小为 n 的随机标记数据集是否线性可分. 这种线性可分的概率 $p_R(\alpha)$ 是 α 的函数; α 是训练点数 n 与数据特征数 (或数据维数) m 之比. 对感知机而言, 特征数等于感知机权重数 d ,³ 故 $\alpha = \frac{n}{d}$. 在这个问题中, 可以把参数 α 理解为分类任务的难度: 训练点越

¹较新的佼佼者之一是 Microsoft 的 GPT-3, 其参数超过 1750 亿个.

² $\mathbb{R}^d$ 中的一组点处于一般位置, 当且仅当任意 $(d+1)$ 个点都不位于任何一个 d 维超平面内. 换言之, 只要不存在三个数据点共线、四个数据点共面等情形, 这组点便处于一般位置. 直观上, 任意随机数据集都处于一般位置.

³一般而言, 感知机由权重 $\mathbf{w}$ 和偏置 b 参数化. 本节余下部分忽略偏置, 因此权重就是全部模型参数

多，难度越大；参数越多，难度越小。

为计算 p_R ，我们可以诉诸几何论证；Thomas Cover 在 20 世纪 60 年代采用了这种方法 [586]。这里则遵循 Elizabeth Gardner 在 1987 年的做法，把问题改写为统计物理学语言 [587]。具体而言，取所有可能权重构成的空间 $\mathbb{R}^d$ ，计算满足随机标记全部约束的权重所占体积。换言之，对于随机标记训练数据 $\mathcal{D} = \{\mathbf{x}^{(k)}, y^{(k)}\}_{k=1}^n$ ，我们计算有多少组权重能够解决其分离问题：

$$V_{n,d} = \int_{\mathbb{R}^d} d\theta \prod_{k=1}^n \delta(f(\mathbf{x}^{(k)}; \theta) - y^{(k)}) . \quad (8.1)$$

δ 函数仅在真实标签等于感知机预测标签时取 1。每加入一个新数据点 k ，就增加一个新约束，可行权重的体积随之缩小。若要至少存在一组这样的权重，体积必须大于零，即 $V_{n,d} > 0$ 。因而，我们把临界任务难度（critical task difficulty） α_c 定义为 $V_{n,d}$ 降至零时的 α 值。若能算出它，就解决了感知机容量问题。

下面对公式作一项修改，使其更接近统计物理学。引入一个有效 Hamiltonian，用来计数被错误分类的训练数据点：

$$H(\theta; \mathcal{D}) = \sum_{k=1}^n \Theta(-f(\theta; x^{(k)})y^{(k)}) . \quad (8.2)$$

这里 Heaviside 函数 $\Theta(\cdot)$ 在自变量为正时等于 1，否则等于 0。我们可以用 $H(\theta; \mathcal{D})$ 的 Boltzmann 因子松弛上面的 Dirac δ 分布。在相差一个乘法常数的意义下，式 8.1 变为

$$\begin{aligned} V_{n,d} &\propto \lim_{\beta \rightarrow +\infty} \beta \int_{\mathbb{R}^d} d\theta e^{-\beta \sum_{k=1}^n \Theta(-f(\theta; x^{(k)})y^{(k)})} \\ &= \lim_{\beta \rightarrow +\infty} \int_{\mathbb{R}^d} d\theta e^{-\beta H(\theta; \mathcal{D})} . \end{aligned} \quad (8.3)$$

于是，式 8.3 中的体积 $V_{n,d}$ 看起来像统计物理学中的正则配分函数。⁴ 这里 β 扮演逆温度的角色，定义为 $1/(k_B T)$ 。因而极限 $\beta \rightarrow \infty$ 对应零温极限。困难在于，这个积分位于所有实数构成的巨大 d 维空间中，因而很难计算。⁵ 此外，指数中的“有效能量”依赖训练集，因此每个训练集都需要单独计算体积 $V_{n,d}$ 。

幸运的是，无序系统（disordered system）物理学可以提供帮助。自 20 世纪 80 年代以来，它一直被用于学习理论 [588, 589, 590, 591, 592, 593, 594]。一旦认出式 8.3 描述的是无序系统，我们就能利用统计物理学的解法计算这个高维积分。下面简要介绍无序系统。无序系统由两类随机变量描述。第一类与系统状态 $s \in \mathbb{R}^d$ 有关。例如，对含 d 个自旋- $\frac{1}{2}$ 的系统， $s \in \{-1, 1\}^d$ ，因为每个自旋都可向上或向下。第二类与自由度之间的相互作用有关，可由耦合 $J \in \mathbb{R}^n$ 参数化。例如， J 可以描述自旋倾向于平行还是反平

θ ，其数目为 d 。

⁴多体经典离散系统的配分函数为 $Z = \sum_i e^{-\beta \varepsilon_i}$ ，其中 i 遍历所有可能微观态， ε_i 是第 i 个微观态的能量。对于由性质 θ 描述、含 n 个全同粒子的连续系统，配分函数为 $Z \propto \int \exp(-\beta \sum_{i=1}^n H(\theta_i)) d\theta_1 \cdots d\theta_n$ ，其中 H 是经典 Hamiltonian。

⁵这也是任何有意义的配分函数都很难计算的原因之一。

行排列. 无序系统中的状态分布由 Boltzmann 分布描述:

$$p(s | J) = \frac{1}{Z_J} e^{-\beta H(s; J)}. \quad (8.4)$$

其中 $H(s; J)$ 是同时依赖 s 和 J 的能量函数, 而 $Z_J = \int_{\mathbb{R}^d} ds e^{-\beta H(s; J)}$ 是配分函数, 并起归一化作用.

作为无序系统的一个例子, 考虑自旋玻璃 (spin glass) [595, 596], 其能量函数为 $H(s; J) = -\sum_{\langle i, j \rangle} J_{ij} s_i s_j$ (类似 Ising 型相互作用, 见式 3.1). 耦合 J_{ij} 独立同分布, 服从正态分布 $p(J_{ij}) \propto \exp -(J_{ij} - J_0)/2J^2$, 其中 J_0 和 J^2 分别为均值与方差. 若所有 J_{ij} 均为正, 系统是铁磁性的, 其基态容易找到. 随机耦合则会带来复杂性和阻挫: 在给定格点, 邻近自旋可能促使某个自旋指向彼此冲突的方向. 寻找这类系统的基态本身就是数值挑战. 在一维中, 问题的解是平凡的, 可由代价按 $\mathcal{O}(n)$ 标度的确定性算法求得; 到了二维, 复杂度上升; 在三维及更高维中, 问题达到 NP 完全 [597].⁶

现在考察式 8.3 的指数, 并把它视为能量函数. 这样一来, 自由能的一个性质可以帮助简化计算.⁷ 具体而言, 自由能具有自平均性 (self-averaging). 若一个随机量具有自平均性, 则满足两个条件: 在热力学极限下, 其平均值与最概然值重合, 并且围绕该平均值的涨落足够小. 换言之, 系统集中于典型状态. 无序系统的自由能通常具有这一性质. 设想把宏观系统分成许多子系统, 而每个子系统仍足够大, 可视为宏观系统. 子系统之间的相互作用可看作表面效应, 相对于体相可以忽略. 因此, 每个子系统都有定义良好的自由能和一种无序实现, 尽管各子系统的取值可能不同. 当子系统数趋于无穷 (且其相互作用在一阶近似下可忽略) 时, 自由能的无序平均就自动等于各无序子系统自由能的平均 [599, 600, 596]. 也就是说, 当 d 足够大时, 系统的物理性质与具体无序实现无关:

$$\frac{1}{d} \ln Z_J \approx \lim_{d \rightarrow \infty} \mathbb{E}_J \left[\frac{1}{d} \ln Z_J \right], \quad (8.5)$$

自由能是广延量, 因此要注意, 在热力学极限下收敛的是每个自旋的自由能. 这一结果极不平凡; 要判定自平均性在何处成立并计算无序平均, 需要副本计算、变分平均场方法和高温展开等工具.⁸ 下一段只介绍式 8.5 背后一个概念的直观图景, 即副本技巧. 希望了解更多细节的读者可参见教程综述 [603, 604].

在统计物理学中, 计算平均只对广延可观测量有意义. 副本法用于对无序变量计算这些平均. 我们特别关心系统自由能 $F_J = -\frac{1}{\beta} \ln Z_J$ 的平均值. 为得到平均自由能 $\mathbb{E}_J[F_J]$, 必须得到配分函数对数的平均值 $\mathbb{E}_J[\ln Z_J]$. 对数的平均很难计算, 但配分函数幂次 $\mathbb{E}_J[Z^n]$ ($n \in \mathbb{N}$) 的平均可以估计. 利用恒等式

$$\ln x = \lim_{n \rightarrow 0} \frac{x^n - 1}{n}, \quad (8.6)$$

⁶已有用强化学习应对这一挑战的方案 [598].

⁷在热力学极限下, 系统自由能为 $F = U - TS = -\frac{1}{\beta} \ln Z$, 其中 U 是系统能量, S 是熵.

⁸值得注意的是, 20 世纪 70 年代发展起来的这些无序系统非严格物理方法 [599, 600, 596], 如今正由数学家建立在更严格的基础上 [601, 602]!

可以写成

$$\mathbb{E}_J[\ln Z] = \lim_{n \rightarrow 0} \frac{\mathbb{E}_J[Z^n] - 1}{n}. \quad (8.7)$$

可以看到，极限 $n \rightarrow 0$ 要求 $n \in \mathbb{R}$. 然而，我们能够先对 $n \in \mathbb{N}$ 计算 Z^n . 配分函数 Z 是形如 $\int e^{-\beta H(s,J)}$ 的积分，故可将 Z^n 写成

$$\begin{aligned} Z^n &= \int ds^{(1)} \dots ds^{(n)} \prod_{a=1}^n e^{-\beta H(s^a, J)} \\ &= \int ds^{(1)} \dots ds^{(n)} e^{-\beta \sum_{a=1}^n H(s^a, J)}. \end{aligned} \quad (8.8)$$

指数中包含对 n 个独立样本（即副本）的求和. 副本技巧是定义函数 $\phi(n)$ ，使其成为指数中函数的解析延拓. 如此一来， $n \in \mathbb{R}$ 成为连续变量，我们就在式 8.7 中取极限 $n \rightarrow 0$. 总之，只要能够计算平均值 $\mathbb{E}_J[Z^n]$ ，就能计算自由能 F_J 的平均值.

最后，利用式 8.5，可以回到式 8.3 中的体积 $V_{d,n}$. 现在把这一体积 $V_{d,n}$ 与自旋系统的配分函数联系起来：自旋 (s) 对应模型参数 (θ)，耦合 (J) 对应训练数据 ($\mathcal{D}$)，后者给出待学习的约束. 沿用上一段的分析可知，当考虑大数据集和大感知机，并保持比值 $\alpha = n/d$ 固定时，给定数据集实现的自由能就等于对数据集分布平均后的自由能：

$$V_{d,n} \simeq \lim_{n \rightarrow \infty} \mathbb{E}_{\mathcal{D}}[V_{d,n} | \mathcal{D}] = V(\alpha). \quad (8.9)$$

因此，只要固定数据分布（无序实现），便可找出使 $V_{d,n} = 0$ 的 α_c ，从而得到感知机容量. 更确切地说，只能在 n 很大（“热力学”）的极限下，对任意固定的 α 计算它，因为 V 实际上以 α 表示.

回顾一下， α_c 表示临界任务难度，在该难度下，满足随机标记约束的感知机权重体积降至零. 因而，当任务难度较低，即 $\alpha < \alpha_c$ 时，随机标记数据线性可分；当任务难度较高，即 $\alpha > \alpha_c$ 时，数据不再线性可分. 所以在热力学极限下，概率 p_R 是 α 的阶跃函数. 图 8.4 中的蓝线给出了来自 Gaussian 分布的实值参数所对应的 p_R .

为展示有限尺寸效应，还可按 Cover 的方法计算有限尺寸下的 $p_R(\alpha)$ [586]. 改变 n 或 d 都能改变 α . 对感知机而言，固定 d 、随 n 增大计算 p_R 关于 α 的函数更容易. 在对应于热力学极限的 $n \rightarrow \infty$ 下，临界值 $\alpha_c = 2$ 处出现相变. 这意味着感知机能够解决的最困难任务，是处于一般位置的训练点数为参数数目的两倍.

有趣的是，使 $V_{d,n} = 0$ 的 α_c 解依赖问题设置，即随机数据分布和参数（自旋）允许取值. 前面的讨论针对 Gaussian 输入分布和实值感知机参数 θ ；对于二元输入和二元参数，临界任务难度不同，如表 5 所示.

本节考察了已有数十年历史、广为人知的感知机容量问题，因此很适合作为教学示例. 我们尤其看到，学习的统计方法关注简单且可解的模型（这里是感知机）. 此外，这种方法力图把学习问题表述成统计问题，例如无序自旋系统；⁹ 对于这类系统，物理学家已经发展出有用的解析工具.

后续小节将简要讨论机器学习与统计物理学交叉领域中若干现代结果. 更详细的综述见文献 [5]. 此外，已故 Naftali Tishby 的讲座“统计物理学与机器学习：三十年回顾”对这些发展作了杰出的回顾.

⁹这也说明二元权重神经网络可能尤其适合物理学家处理：它们就是自旋-1/2 问题！




图 8.4: 随机标记数据线性可分的概率 p_R 关于任务难度 $\alpha = \frac{n}{d}$ 的函数. 有限尺寸结果由 Cover 解析得到 [586].

表 5: 感知机容量取决于数据分布和权重类型. 容量表示为可能解的体积降至零, 即 $V(\alpha_c) = 0$ 时的最小任务难度 $\alpha_c = \frac{n}{d}$.

	数据分布	临界任务难度 α_c
1	Gaussian 输入 实值权重 $p(\mathbf{x}_i^{(k)}) = \mathcal{N}(\mathbf{x}_i; 0, 1)$ $\boldsymbol{\theta} \in \mathbb{R}^d$	$\alpha_c = 2$
2	二元输入 二元权重 $p(\mathbf{x}_i^{(k)}) = \text{Bernoulli}(0.5)$ $\boldsymbol{\theta} \in \{-1, 1\}^d$	$\alpha_c \approx 0.83$

8.1.2 教师-学生范式：研究泛化的玩具模型

本节的动机是破解泛化之谜；泛化是指模型对训练期间未见数据作出正确预测的能力. 不过，本节的目标并非构建新的实用机器学习模型，也不是按泛化能力区分现代模型的优劣，而是理解实用的现代机器学习模型为何能如此良好地泛化. 为此，我们把学习任务的所有要素（例如模型、优化方法和数据）都化为最简单的形式. 帮助我们完成这一宏大任务的玩具模型属于教师-学生范式.

教师-学生范式包含两个主要要素：教师是生成数据的模型，学生则试图学习教师生成的数据. 教师由输入分布 $p_x(\mathbf{x})$ （例如 Gaussian 分布或二元分布）和输入-输出规则 $p(y_t | \mathbf{x}) = f_t(\mathbf{x}, \boldsymbol{\theta}^*)$ 构成. 暂且假设教师是一个感知机. 除输入-输出规则外，还可假设权重服从真实分布 $p_\theta(\boldsymbol{\theta})$ ，教师模型参数 $\boldsymbol{\theta}^*$ 从中抽取. 一旦确定教师的形式，它便能生成训练数据： $\mathcal{D} = \{\mathbf{x}^{(k)}, y_t^{(k)}\}_{k=1}^n = \{\mathbf{x}^{(k)}, f_t(\mathbf{x}^{(k)}, \boldsymbol{\theta}^*)\}_{k=1}^n$.

第二个要素是学生，其目标是学习训练数据背后的分布. 在教师-学生方案中，我们确切知道数据生成分布是什么. 因此，很容易区分仅仅拟合训练数据的学生（泛化有限）与恢复教师输入-输出规则的学生（完美泛化）. 换言之，我们能够度量学生的泛化能力.

为继续采用教师-学生策略，既要选定学生模型 $f_s(\mathbf{x}, \boldsymbol{\theta})$ ，也要选定学习策略. 先考虑最简单的情形：学生与教师一样，也是感知机. 训练时可以采用标准的经验损失最小

化策略，例如

$$\boldsymbol{\theta}^* = \underset{\boldsymbol{\theta}}{\operatorname{argmin}} \left\{ \sum_{k=1}^n \mathcal{L}(y_t^{(k)}, f_s(\mathbf{x}^{(k)}, \boldsymbol{\theta})) \right\}. \quad (8.10)$$

这里要最小化教师输出 $y_t^{(k)}$ 与学生输出 $y_s^{(k)} = f_s(\mathbf{x}^{(k)}, \boldsymbol{\theta})$ 之间的给定距离. 另一种选择是考虑如下参数的 Bayesian 后验 (Bayesian posterior) 分布，并按此分布抽取参数值：

$$p(\boldsymbol{\theta} | \mathcal{D}) \propto \prod_{k=1}^n p(y_t^{(k)} | \boldsymbol{\theta}, \mathbf{x}^{(k)}) p(\boldsymbol{\theta}). \quad (8.11)$$

式 8.11 表示后验分布，即给定数据集 $\mathcal{D}$ 和关于学生权重的先验假设 $p(\boldsymbol{\theta})$ 后，对学生模型权重 $\boldsymbol{\theta}$ 的信念.

例如，假设采用均方误差损失，则给定权重 $\boldsymbol{\theta}$ 时，学生的泛化误差定义为整个数据分布上的期望误差：

$$\mathcal{E}_g(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{x}, y} [(y - f_s(\mathbf{x}, \boldsymbol{\theta}))^2], \quad (8.12)$$

在最佳情形下，学生模型 $f_s(\cdot, \cdot)$ 与生成数据所依据的教师模型 $f_t(\cdot, \cdot)$ 完全相同. 学生与教师相同时，我们称这种设置为 Bayes 最优 (Bayes optimal)，并把学生的 Bayes 误差 (见节 2.3) 定义为

$$\mathcal{E}_g^{\text{opt}}(\mathcal{D}) = \mathbb{E}_{\boldsymbol{\theta}} [\mathbb{E}_{\mathbf{x}, y} [(y - f_s(\mathbf{x}, \boldsymbol{\theta}))^2] | \mathcal{D}], \quad (8.13)$$

它是从式 8.11 的后验分布中抽取学生参数 $\boldsymbol{\theta}$ 所得到的平均误差. 从信息论角度看，这是一个基本量：在假设学生完全知道问题形式的前提下，它量化训练数据集 $\mathcal{D}$ 提供了多少关于权重 $\boldsymbol{\theta}$ 的信息.

利用上一小节中的同一套工具 (无序平均、热力学极限和副本计算)，可以得到

$$\mathcal{E}_g^{\text{opt}}(\mathcal{D}) \xrightarrow{n \rightarrow \infty} \mathbb{E}[\mathcal{E}_g^{\text{opt}}(\mathcal{D}) | \mathcal{D}] = \mathcal{E}_g^{\text{opt}}(\alpha). \quad (8.14)$$

这里，极限泛化误差再次成为比值 $\alpha = \frac{n}{m}$ 的函数；该比值是数据点数与数据特征数或权重数之比. 我们不再像计算容量时那样把这个比值解释为分类任务难度. 对泛化问题而言，更有用的理解是把 α 看作样本复杂度，即可用于推断输入-输出规则的训练数据量.

下面各内部段将考察若干不同教师-学生配对的泛化行为.

式 8.14 的泛化误差绘于图 8.5. 我们可以把极限下的 Bayes 最优泛化误差 (图 (a)、(b) 中的红线) 与有限 m 下通过最小化损失函数训练感知机的结果作比较，例如用梯度下降进行 logistic 回归 (蓝色方块). 对二元权重，图 (a) 中出现一阶相变 [592, 593]；对实值权重，图 (b) 中的泛化误差平滑下降 [605]. 两种情形下，最优泛化误差与采用梯度下降的 logistic 回归之间都存在计算鸿沟.

最后，还可以在学生感知机采用广义近似消息传递 (generalized approximate message passing (GAMP)) 算法学习时研究同一泛化误差. 这些方法的介绍见文献 [606,




图 8.5: 泛化误差关于任务难度 α 的函数; α 是训练点数与学生模型参数数之比, 感知机参数分别为 (a) $\theta \in \mathbb{R}^d$ 或 (b) $\theta \in \{-1, 1\}$. 红线是精确的 Bayes 最优泛化误差. 蓝色方块表示以基于梯度的误差最小化精调感知机所得结果. 两类结果之间存在计算鸿沟; 消息传递算法使 (a) 中的鸿沟缩小, 使 (b) 中的鸿沟消失. 黑色圆点是用 GAMP 在 $n = 10^4$ 时得到的结果, 绿线表示状态演化的结果, 后者近似 $n \rightarrow \infty$ 的极限. 改编自文献 [605], 采用 CC BY 4.0 DEED 许可.

[607, 604]. 对本节而言, 只需知道这类算法提供了凸优化之外的另一种选择, 并能高效计算基于图的量 (例如感知机或神经网络中的量); 这些量从式 8.12 至式 8.14 一类分布中采样. 更重要的是, 它们的渐近性能 ($n, d \rightarrow \infty$ 且 $n/d = \alpha$) 可以用所谓的状态演化 (state evolution (SE)) 作严格分析.

有了这些知识, 现在可以看到, 图 8.5 中 GAMP 得到的泛化误差比梯度下降优化的结果更接近 Bayes 误差. 图 (b) 中鸿沟完全消失; 图 (a) 中 GAMP 与精确 Bayes 误差之间仍有计算鸿沟. 这一范围称为困难相 (hard phase). 它源于实践中计算时间只能限制在多项式范围内. 有趣的是, 在这一感知机学习问题的困难相中, 目前没有已知高效算法能够胜过 GAMP [605].

到目前为止, 教师和学生都用感知机建模. 现在可以转向更复杂的模型. 本节余下部分使用两种在统计物理学中历史悠久的特殊两层神经网络. 首先考虑委员会机 (committee machine) [608, 609], 如图 8.6(a) 所示. 当输入特征数 m 和数据规模 n 趋于无穷, 同时隐藏单元数保持有限时, 可以对它作解析处理. 这里尤其采用分析更简单的软委员会机 (soft committee machine). 在软委员会机中, 只训练第一层参数 θ_1 , 其数目为 $d_1 = d = mD$; 其中 m 是特征数, D 是隐藏单元数. 第二层固定, 并且教师与学生的第二层参数完全相同.

本节使用的第二种神经网络是图 8.6(b) 所示的随机特征模型 (random feature model) [610, 611]. 有趣的是, 它之所以能够解析分析, 是因为第一层固定, 参数设为随机值. 这些参数的数目同样为 $d_1 = d = mD$, 因此只有第二层参数可训练. 随机第一层背后的思想是: 把低维输入投影到维数高得多的空间, 会使数据更易分离, 随后单层神经网络便能成功处理这些数据.¹⁰ 还要注意, 随机特征模型可以有任意多个隐藏单

¹⁰换言之, 可以把这种投影理解为将输入数据映射到特征空间, 正如节 4.2 关于核方法的讨论. 有趣的是, 文献 [610, 611] 表明, 与投影到优化后的特征空间相比, 把数据随机投影到特征空间并不会差很多;




图 8.6: 本节所用两层神经网络的示意图. (a) 软委员会机. 第一层参数 $\theta_1 \in \mathbb{R}^{m \times D}$ 可训练, 第二层参数 $\theta_2 \in \mathbb{R}^{D \times 1}$ 则取为与教师参数相同. 当 $m \rightarrow \infty$ 且 $D = O(1)$ 时, 可以对它作解析处理. (b) 随机特征模型. 第一层固定为随机参数值, 第二层可训练. 改变隐藏单元数可以研究过参数化. 在分析中, 隐藏单元数 $D \rightarrow \infty$ 与输入数 $m \rightarrow \infty$ 成线性标度, 即 $m/D = O(1)$.

元, 尤其可以多于输入特征数, 因此能够用来研究过参数化.

现在可以用更复杂的模型研究泛化. 这里采用软委员会机, 并暂且令教师和学生具有相同的架构. 问题表述保持不变: 学生委员会机学习教师委员会机生成的数据时, 我们计算式 8.14 给出的泛化误差 [609]. 对含两个隐藏神经元的委员会机, 泛化误差绘于图 8.7(a)–(b). 与前面类似, 图 (a) 表明, 对于实值权重, 由 GAMP 和状态演化得到的泛化误差等于 Bayes 误差; 而对图 (b) 的二元权重, 两种误差之间存在计算鸿沟.

这次还要考察学生与教师隐藏神经元之间的重叠, 它逐个神经元度量教师和学生的相似性. 更确切地说, 我们考察重叠矩阵 (overlap matrix) $\mathbf{Q} = [q_{jj'}] = \frac{1}{m} \sum_{i=1}^m \Theta_{1,ij}^* \theta_{1,ij'}$, 其中 Θ_1 和 θ_1 分别为教师与学生的第一层参数. 结果表明, 存在所谓的专门化相变 (specialization phase transition) [612, 613].

在任务复杂度较低的范围, 学生委员会机的两个隐藏单元学习同一个函数. 越过临界 α 后, 可用数据已经足够, 学生的隐藏神经元开始专门化: 每个学生神经元选择一个不同的教师神经元并向其收敛. 与非专门化相相比, 专门化相对应更低的泛化误差, 见图 8.7.

对于教师和学生都含两个隐藏神经元 ($D = 2$) 的委员会机, 实值权重在 $\alpha_c \approx 2$ 处发生专门化, 二元权重则在 $\alpha_c \approx 1.5$ 处发生专门化. 这意味着, 要使神经元专门化, 训练数据量至少须为数据特征数 m 的 2 倍或 1.5 倍, 即大致与第一层参数数目 $d_1 = 2m$ 相当. 当教师和学生委员会机都含大量隐藏神经元 ($D \gg 2$) 时, 也有类似现象.

对实值权重, 可以把泛化误差的相图绘成重标度任务难度 $\tilde{\alpha} = \frac{\alpha}{D} = \frac{n}{Dm}$ 的函数, 如但随机化比优化便宜得多.




图 8.7: 委员会机的泛化误差和专门化关于任务难度 $\alpha = \frac{n}{m} \propto \frac{n}{d}$ 的函数; 该难度是训练点数与输入特征数之比. 考虑 (a) $\theta \in \mathbb{R}^{m \times D}$ 、 $D = 2$ 的委员会机, 以及 (b) $\theta \in \{-1, 1\}^{m \times D}$ 、 $D = 2$ 的委员会机. 黑线是精确的 Bayes 最优泛化误差, 黑点是用 GAMP 研究委员会机得到的结果. 橙色和蓝色的线与点表示学生委员会机的两个隐藏神经元同教师委员会机的两个隐藏神经元之间的重叠, 分别由 GAMP 和状态演化计算. 可以看到, 专门化导致泛化误差快速下降. (c) 把图 (a) 推广到大量隐藏神经元 D 的情形; 相图针对任务难度 $\tilde{\alpha} = \frac{\alpha}{D}$ 计算. 改编自文献 [609].

图 8.7(c) 所示. 总计得到三个不同的相: 两个相分别对应专门化与非专门化隐藏神经元; 在专门化相之上还存在一个计算鸿沟, 此时模型原则上已有足够信息实现专门化, 却因优化方法的局限而无法做到.

正如引言中已经提到的, 现代机器学习中最令人困惑的现象之一, 是高度过参数化模型所具有的泛化能力. 在现实设置中, 很自然会把模型的过参数化程度理解为模型参数数目 d 与可用训练数据点数 n 之比. 令人惊讶的是, 实践中参数数目 d 很大的模型能够从少得多的训练数据点中提取有意义的关系. 而在教师-学生方案中, 我们可以更严格地定义过参数化, 因为描述输入-输出规则所需的“真实”参数数目——即教师参数数目——可由我们直接获得. 因此, 可以把过参数化程度理解为学生参数数目与教师参数数目之比. 特别地, 学生的参数可以远多于教师. 所以, 要研究过参数化, 就必须采用架构不匹配的教师与学生. 关键在于, 这种架构不匹配意味着学生不再能够达到 Bayes 最优误差.

本节余下部分研究过参数化学生模型的泛化误差. 这次选用前面已在图 8.6(b) 中介绍的随机特征模型作为学生. 分析要求把模型第一层的权重固定为随机值; 学生第二层的参数数目相对于教师则可以改变.¹¹ 由此, 我们可以完全控制学生的过参数化程度. 我们将在节 8.1.4 中回到委员会机的过参数化研究.

采用学生随机特征模型后, 我们便可以研究泛化误差随过参数化程度 $\frac{1}{\alpha} = \frac{d}{n}$ 的变化, 其中 $d = d_1$ 是学生第一层固定随机参数的数目. 由于学生不再能够达到 Bayes 最

¹¹ 文献 [614] 还对完全相同的设置作了如下解释: 教师用作用于低维潜在空间的感知机生成标签, 而输入数据则由一个单层生成神经网络从该潜在空间生成; 随后在输入数据-标签对上训练一个学生感知机.




图 8.8: 在教师-学生模型架构不匹配、且学生为随机特征模型时, 泛化误差关于模型参数数目与训练数据点数之比的函数. 第一列 (第二列) 给出回归 (分类) 问题中的泛化误差. 上排采用次优正则化强度, 此时泛化误差曲线呈现双下降; 下排采用最优正则化, 此时双下降消失. 改编自文献 [614].

泛化误差, 我们需要改变训练目标, 例如改用带 ℓ_2 正则化的均方误差. 借助多种解析工具, 仍然可以近似学生的泛化误差, 并把它绘成过参数化程度 $\frac{d}{n}$ 的函数. 文献 [614] 分析了不同正则化强度下回归与分类任务的泛化误差, 其结果如图 8.8 所示. 左列 (右列) 给出回归 (分类) 问题中, 不匹配学生在最优和次优正则化强度下的泛化误差.

值得注意的是, 当学生与教师的架构不匹配时, 泛化误差曲线呈现出特征性的双下降. 此外, 选择最优正则化会消除第一次误差下降, 使泛化误差随模型参数数目增加而持续降低.

因此, 这些玩具模型结果为双下降现象的起源提供了线索: 当学生与教师的架构不匹配, 且所选正则化强度为次优时, 就会出现双下降. 有趣的是, 文献 [614] 还表明, 双下降中最初泛化误差上升的幅度取决于问题是分类任务还是回归任务.

总之, 对玩具模型的研究表明, 泛化误差大于 Bayes 最优误差可能有多种原因. 一般而言, 泛化能力取决于:

- 数据生成模型 (教师) 与学习模型 (学生) 的架构是否不匹配;
- 模型旨在求解回归问题还是分类问题;
- 优化方法、目标函数和可用计算时间的选择;
- 样本复杂度, 即有多少训练数据可用; 对教师-学生委员会机而言, 还包括神经元的专门化程度.

8.1.3 数据结构模型

到目前为止, 在研究泛化误差的来源时, 我们主要改变教师与学生模型的架构; 这些架构规定了数据背后的输入-输出规则结构. 特别地, 我们只考虑过所有输入特征彼

此独立的随机输入数据集. 显然, 这种各向同性数据虽然简化了解析分析, 却相当不现实. 理想情况下, 我们希望研究 MNIST [31] 或 ImageNet [34] 等典型数据集, 但它们难以解析处理. 因此, 我们先从白噪声数据集向前迈一步, 利用教师-学生范式研究数据各向异性对泛化误差的影响. 为此, 我们采用显著与弱特征模型 (salient and weak feature model) [615]. 在这类特征模型中, 数据仍服从 Gaussian 分布 (与前面多数小节相同), 即 $\mathbf{x} \sim \mathcal{N}(0, \Sigma_{\mathbf{x}})$; 但其协方差不像 $\Sigma_{\mathbf{x}} = I_d$ 时那样各向同性, 而是各向异性的:

$$\Sigma_{\mathbf{x}} = \begin{bmatrix} \sigma_{x,1} I_{\phi_1 d} & 0 \\ 0 & \sigma_{x,2} I_{\phi_2 d} \end{bmatrix}, \quad (8.15)$$

这里 $\sigma_{x,1} \gg \sigma_{x,2}$, 而 $\phi_{1/2}d$ 表示受方差 $\sigma_{x,1/2}$ 影响的数据特征数 (等于感知机参数数目), 其中 $\phi_1 + \phi_2 = 1$. 受大方差 $\sigma_{x,1}$ 影响的参数构成显著子空间 (salient subspace), 受小方差 $\sigma_{x,2}$ 影响的参数则构成弱子空间 (weak subspace), 如图 8.9(a) 所示. 我们假设弱子空间远大于显著子空间, 即 $\phi_2 \gg \phi_1$.

如果把这种结构加入输入数据, 并在架构不匹配的情形下运行教师-学生方案 (这里教师是感知机, 学生是随机特征模型), 那么在高维极限下仍能精确计算泛化误差 [615]. 重要的是, 此时泛化误差依赖于输入数据的各向异性. 特别地, 它取决于教师感知机相对于弱数据子空间和显著数据子空间的取向, 如图 8.9(a) 所示. 虚线超平面表示教师感知机对输入空间的划分, 并垂直于感知机参数向量 θ . 该向量可以用不同方式相对于数据各向异性取向. 若 θ 与显著子空间对齐, 超平面便沿弱子空间切分; 此时与区分数据点有关的唯一子空间是数据方差集中的显著子空间, 弱子空间可以有效忽略. 在这种情况下, 数据结构使问题具有与显著空间 $\phi_1 d$ 对应的较小有效维数, 因而更易求解. 反之, 若 θ 与弱子空间对齐, 数据结构的影响便可忽略, 因为学生需要沿一个数据方差小于典型数据方差的轴作区分. 此时问题与 (完全) 各向同性情形非常相似.




图 8.9: 进入教师-学生方案的数据结构. (a) 数据空间可分为弱子空间和显著子空间, 其中数据分别具有小方差和大方差. 参数为 θ 的教师感知机可以与显著子空间对齐 (蓝色向量), 也可以不对齐 (紫色向量). 当 θ 与显著子空间对齐时, 由教师指定的分类任务 (表示为分隔数据的直线) 比各向同性情形更容易. (b) 模型能够探测数据中存在的结构, 因此结构化情形的泛化误差低于完全各向同性情形. 各向同性数据的结果, 与教师感知机不对齐时各向异性数据的结果相似. 泛化曲线呈现双下降. 改编自文献 [615].




图 8.10: 过参数化委员会机的学习动力学. 在 (a)–(b) 中, 只允许学生的一层可训练, 另一层固定; 在 (c)–(d) 中, 训练整个学生模型. (a)、(c) 泛化误差随学生过参数化程度的变化; 当学生隐藏单元数 D 大于教师隐藏单元数 T 时, 就会发生这种过参数化. (b)、(d) 学生的自重叠 (Q 矩阵), 以及过参数化学生与教师之间的重叠 (R 矩阵). 向量 w 包含学生第二层的权重. 改编自文献 [616].

数据结构对泛化曲线的影响如图 8.9(b) 所示; 这里泛化曲线绘成学生模型参数数目与数据维数之比 $\frac{d}{m}$ 的函数. 有趣的是, 训练会在泛化误差因过拟合而达到峰值之前探测到数据结构, 并相对于各向同性情形改善泛化误差. 为什么结构会有所帮助? 这是因为在实践中, 模型可以忽略弱子空间而专注于显著子空间, 从而降低问题的维数. 即使在高度过参数化范围 ($\frac{d}{m} = 10^3$), 各向异性情形的泛化误差低于各向同性情形这一结论仍然成立. 此外, 数据结构的存​​在还会加剧双下降现象. 注意, 这两种效应都只在教师感知机与显著子空间对齐时发生; 否则, 该设置与各向同性情形非常相似.

事实证明, 利用显著与弱特征模型, 教师–学生范式还可以处理更多问题. 特别地, 文献 [615] 的作者考察了数据结构与机器学习问题其他要素 (例如损失函数选择) 之间的相互作用. 分别采用均方误差损失和 logistic 损失重新计算图 8.9(b) 中的量, 可以观察到 logistic 损失会削弱过拟合峰. 因此, logistic 损失似乎能更充分地利用已有数据结构. 还可以把两种损失函数的泛化误差计算为教师–数据对齐程度的函数, 从而进一步确认这一点. 如前所述, 这种对齐决定了问题中有效存在多少数据结构. 与上述结果一致, 对齐程度越高, 均方误差损失与 logistic 损失之间的泛化误差差距就越大.

8.1.4 学习动力学

最后, 可以利用上述教师–学生方案研究学习动力学及其对模型过参数化的依赖. 学习的一个简化模型是在线学习 (online learning), 相关分析始于 20 世纪 90 年代. 在线学习向模型输入数据流, 其中每个数据点只被模型看到一次. 我们根据这个样本构造损失函数, 并按该损失函数的梯度更新参数. 事实上, 每遇到一个数据点, 就进行一次参

数更新. 因此, 优化步数等于已经见过的训练数据点数. 如果取连续时间极限与高维极限, 并对所有随机变量求平均 (若假设不同时刻的样本不相关, 就可用副本方法完成), 便能再次显式计算泛化误差. 特别地, 我们可以计算泛化误差在训练期间如何变化. 换言之, 可以跟踪整个训练过程中模型预测的质量.

早在 20 世纪 90 年代, 人们就已经对感知机和委员会机作过这种分析 [617, 618]. 例如, 结果表明, 在线训练期间采用不同学习率时, 泛化误差会以不同收敛速率下降. 最近, 考虑过参数化影响的同类分析又被用于软委员会机 [616]. 在教师-学生模型匹配、且训练仅限于学生单层的简化情形下, 结果表明: 学生神经元一旦发生专门化并与教师神经元达到较大重叠, 泛化误差就会下降. 我们还可以利用图 8.6(a) 所示的委员会机, 在数据特征数 $m \rightarrow \infty$ 、采用 sigmoid 激活函数 $g(x) = \text{erf}(x/\sqrt{2})$ 的范围内, 研究过参数化对学习动力学的影响. 这里把泛化误差研究为学生隐藏单元数 D 与教师隐藏单元数 T 之比 $\frac{D}{T}$ 的函数.

图 8.10 给出了这类过参数化学生在线学习的两种情形. 第一种情形见 (a)–(b): 只有学生模型的第一隐藏层可以训练, 第二隐藏层的参数固定, 并与教师对应层完全相同. 第二种情形见 (c)–(d): 学生的两层都参与训练. 图 (a) 表明, 泛化误差实际上随学生可训练层的尺寸增大而上升, 证明过参数化在某些情形下可能有害. 为理解原因, 我们分析训练结束时的教师-学生重叠 $\mathbf{R} = [R_{it}]$, 其中每个矩阵元度量第 i 个学生节点与第 t 个教师节点的权重相似性. 我们还研究不同学生节点权重彼此之间的重叠, 即 $\mathbf{Q} = [Q_{ij}]$, 并在图 (b) 中绘出这两个矩阵. 可以看到, 对软委员会机而言, 只有与教师神经元数目相等的那部分学生神经元发生专门化; 其余神经元只会拾取可用数据中的噪声, 从而损害泛化.

不过, 如果允许所有层都参与训练, 就会观察到截然不同的行为. 图 (c) 表明, 随着学生模型过参数化程度提高, 泛化误差反而下降. 这一次, 所有神经元都学到了与教师神经元有关的内容. 因而, 新增神经元是有益的: 每个教师神经元都可以由一组学生神经元共同学习, 这有助于对教师参数的估计进行“去噪”.

展望与开放问题

本节已经说明如何使用统计物理学的解析工具研究机器学习问题. 特别地, 我们讨论了感知机容量这一奠基性问题. 随后, 我们聚焦于研究泛化误差的一个强大范式: 教师-学生方案. 该方案可以包含多种修改, 从而处理学习问题的所有要素.

我们可以研究不同的教师与学生架构, 而且二者可以不匹配. 前面已经给出感知机、委员会机和随机特征模型的结果; 更一般地, 还可以像文献 [619] 那样, 以预训练生成模型作为教师 (更详细的介绍见节 7.2.2). 也可以分析比显著与弱特征模型所提供的数据集更复杂的数据集. 特别地, 可以在标准基准数据集上进行模拟, 以确认从简单模型解析分析中获得的直觉 [615]; 这类数据集包括 MNIST [31] 和 CIFAR [33]. 最后, 还可以超越在线梯度下降, 利用动力学平均场理论 (dynamical mean-field theory) 研究多遍随机梯度下降 (multi-pass stochastic gradient descent) (即多次遇到相同数据点) [620], 从而逐步接近现代优化方法.

此外, 还可以研究大型机器学习架构的容量, 这与简单感知机形成对照. 统计工具在量子机器学习 (quantum machine learning (QML)) 研究中也发挥着日益重要的作用.

用. 例如, Gardner 方法已成功应用于量子感知机 (quantum perceptron) [621, 622] 和量子神经网络 [623]. 特别地, 结果表明, 在容量方面, 量子感知机相对于经典对应物具有某些优势 [622]. 此外, 已有工作提出用教师-学生方案系统比较不同的量子神经网络架构 [624].

最后, 还有一些工作研究机器学习模型学习动力学中的相 [625, 626].

延伸阅读

- Gabri  , M. (2020). *Mean-field inference methods for neural networks*. J. Phys. A: Math. Theor. 53, 223002. 本节提及的平均场方法综述; 尤其介绍了高温展开、副本方法和消息传递算法的推导原理 [604].
- Zdeborov  , L. (2020). *Understanding deep learning is also a job for physicists*. Nat. Phys. 16, 602–604. 简短而亲切地介绍物理学如何助力机器学习 [585].
- 2022 年 7 月 4–29 日在法国 Les Houches 举办的机器学习统计物理暑期学校的课程录像.
- 为量子物理与化学中的机器学习暑期学校教程编写的 Jupyter notebooks [2].
- Castellani, T. & Cavagna, A. (2005). *Spin-glass theory for pedestrians*. J. Stat. Mech. P05012. 关于自旋玻璃平均场方法的教学性综述 [603].

8.2 量子机器学习

本节探索另一个方向: 如何利用量子信息和量子硬件解决数据驱动任务. 这一新兴领域称为量子机器学习 (QML)¹². 该领域始于以获得潜在全量子优势 (fully quantum advantage) 为目标的量子算法研究. 近年来, 另一个方向日益受到关注: 研究混合量子-经典算法 (hybrid quantum-classical algorithm) (也常称为量子增强算法), 其中一部分算法在量子器件上执行. 随着新的量子计算实验平台不断发展, 研究者正寻找为这些混合算法量身定制的应用, 并试图确定这类系统能否产生量子优势, 以及量子优势如何产生. 尽管量子优势将意味着一项突破, 但研究在这些混合器件上运行的量子增强算法本身就是一个有趣的问题, 并可能促成令人振奋的物理发现.

下文将概述该领域近期取得的进展. 我们无意给出完整综述, 而是介绍若干选定主题. 在最后一节, 我们会为感兴趣的读者列出该领域近期的综述文献.

8.2.1 基于门的量子计算

下文将重点介绍基于门的量子计算 (gate-based quantum computation). 这些概念将在本节各处使用.

¹²文献中的量子机器学习 (QML) 通常既包括量子增强机器学习 (quantum-enhanced machine learning), 也包括应用于量子问题的机器学习, 例如用于量子信息处理的机器学习. 本节用 QML 专指量子增强机器学习. 关于这一约定的详细讨论见节 8.2.2.




图 8.11: 量子电路图示例, 其中包含两个已初始化的量子比特 q_0 和 q_1 , 以及三种不同的量子门: 均作用于 q_0 的 Hadamard 门 H 和 σ_x 门 X, 以及一个双量子比特门 (CNOT). 最后一个元素是对 q_0 和 q_1 的测量.

基于门的量子计算最常见的构件是量子比特 (qubit) 和量子门. 基于门的量子算法由一系列作用于量子比特的门操作和测量组成, 可以方便地表示为量子电路.

量子比特是二能级量子系统, 可以通过在多种实验平台中隔离两个自由度来实现, 例如光子平台 [627, 628]、超导电路 [629]、囚禁离子 [630], 或光镊中的 Rydberg 原子 [631, 632]. 执行计算时, 量子计算机利用量子门改变量子比特的状态, 或使量子比特发生纠缠.

量子门是幺正操作, 可以用幺正矩阵表示. 这些矩阵的维数取决于量子门作用的量子比特数, 其维数随量子比特数呈指数增长.

单量子比特门的例子包括 Hadamard 门和 Pauli-X 门; 在单量子比特基 $\{|0\rangle, |1\rangle\}$ 中, 它们写为

$$H = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad (8.16)$$

也可以考虑参数化门, 例如单量子比特旋转门

$$R_X(\theta) = \frac{1}{\sqrt{2}} \begin{pmatrix} \cos \theta & -i \sin \theta \\ -i \sin \theta & \cos \theta \end{pmatrix}, \quad (8.17)$$

它以角度 θ 参数化.

双量子比特门的一个例子是受控非门 (controlled NOT gate) (CNOT); 在双量子比特基 $\{|00\rangle, |01\rangle, |10\rangle, |11\rangle\}$ 中, 它写为

$$\text{CNOT} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}. \quad (8.18)$$

一般而言, 量子电路可以用量子电路图表示, 图 8.11 给出了一个例子. 每条线对应一个量子比特. 该电路含有两个作用于单个量子比特的门 (X 和 H), 以及一个作用于两个量子比特的纠缠门 (CNOT). 电路图的最后一部分是测量; 它与各个量子比特相互作用, 迫使量子比特坍缩到两个能级之一. 由于测量具有破坏性, 为了从量子电路中恰当地提取相关信息, 必须仔细选择测量集合.

8.2.2 什么是量子机器学习？

为了更好地理解量子机器学习 (QML)，先来看图 8.12(a). 通常，机器学习算法运行在经典数据 (classical data) 上，例如图像分类或自然语言处理；此时由经典算法处理经典数据 (CC). 本书主要关注经典机器学习应用于量子数据 (quantum data) 的情形 (CQ)，例如处理量子态. 另一方面，量子机器学习 (QML) 把量子器件集成到机器学习算法中. 因而，算法可以是量子的，数据则可以是经典的 (QC) 或量子的 (QQ). 本节主要关注 QC 情形，因为 QQ 情形仍处于发展的早期阶段 [633, 634, 635, 636].




图 8.12: (a) 不同数据类型和算法类型的表格. (b) 单量子比特分类任务示例的示意图.

下面讨论一个基本示例，以介绍 QC 量子机器学习语境下经过调整的机器学习构件. 考虑环上一维数据的分类问题，图 8.12(b) 直观画出了这一量子机器学习分类问题的每个步骤. 首先，把经典数据 (x_i, y_i) 编码进量子计算机. 例如，可以通过参数化么正操作 U_{θ, x_i} 的作用，把数据点编码到单个量子比特上，其中 θ 是该么正变换的参数（例如节 8.2.1 介绍的 $R_X(\theta)$ ）. 随后进行测量，并把测量输出 y_{pred} 定义为标签（这里为 1 或 0）. 接着，构造依赖预测标签和真实标签（ground-truth label）的损失函数 $\mathcal{L}(\theta)$. 可以看到，这里的量子增强部分对应于在量子计算机上计算 y_{pred} . 定义损失函数后，可以在经典计算机上用任意选定方法执行最小化，例如梯度下降或无梯度优化器（gradient-free optimizer）（如 Nelder-Mead 方法）. 在这个简单例子中，训练具有直观解释. 最初，么正操作的权重 θ 随机分布；因此，经典数据到量子比特的映射也随机分布在 Hilbert 空间中. 优化过程旨在把两个类别推向 Bloch 球（Bloch sphere）的相反两极. 因而，对训练后的权重 θ^* ，我们预期 Bloch 球上的数据会更加有序.

8.2.3 理想量子计算机

计算复杂性理论（computational complexity theory）是计算机科学的一个领域，重点依据计算问题所需的资源对问题进行分类. 特别地，经典计算机擅长求解属于两个复杂度类的问题：可在多项式时间内求解的 P 类，以及有界误差概率多项式时间（bounded-error probabilistic polynomial time (BPP)）类. 假如拥有一台理想量子计算机，一个

自然问题便是：是否存在某类问题，能在量子计算机上以多项式时间求解，却需要经典计算机花费指数时间？在这一语境下，人们定义了另一个复杂度类；粗略而言，它包含所有能由量子计算机在多项式时间内求解并验证的问题，即有界误差量子多项式时间 (bounded-error quantum polynomial time (BQP)) 类。

最早提出的指数加速量子算法之一来自离散 Fourier 变换。量子 Fourier 变换 (quantum Fourier transform (QFT)) 算法 [637] 只需使用由 $\mathcal{O}(n \log(n))$ 个量子门组成的量子电路，就能对 2^n 个振幅执行离散 Fourier 变换；经典算法执行同一任务则需要 $\mathcal{O}(n2^n)$ 次操作。另一个具有这种加速的例子是用于高效整数分解的 Shor 算法 (Shor algorithm) [638]。它利用量子相位估计算法 (quantum phase estimation algorithm) [639] 和量子 Fourier 变换的构件，相对于这一任务的最佳经典算法获得指数加速。另一个非常著名的算法是 Harrow–Hassidim–Lloyd 算法 (Harrow–Hassidim–Lloyd algorithm (HHL)) [640]，它被设计用于求解线性方程组

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad (8.19)$$

其中 $\mathbf{A}$ 是条件数为 k 的 $n \times n$ 稀疏矩阵。该算法能在 $\mathcal{O}(\log(n)k^2)$ 时间内找到向量 $\mathbf{x}$ ，而标准算法通常需要 $\mathcal{O}(n^2)$ 时间；就系统规模而言，这是一种指数加速。不过，有一点至关重要：经典算法直接返回解，而 HHL 算法把解编码在量子态中，必须反复测量才能将其读出。

机器学习算法高度依赖线性代数，而线性代数通常构成机器学习计算成本的很大一部分。例如，支持向量机 (SVM) 分类问题通常需要二次规划 (SVM 的一般思想见节 2.4.3)，但一种特殊形式的 SVM¹³ 可归结为求解线性方程组。在这一语境下，量子计算机可能加速这类代价高昂的操作。例如，已有工作把 HHL 算法应用于 SVM [641] (四量子比特量子计算机上的近期实验实现见文献 [642]) 和数据拟合 [643]。值得注意的是，相对于经典算法，HHL 算法究竟能提供多大量子加速仍有争议 [644]。另一个注意事项是，经典数据必须能够高效编码进量子算法；这是该领域仍须解决的另一问题。

8.2.4 含噪中等规模量子时代

到目前为止，我们只考虑了用理想量子计算机运行 Shor、量子 Fourier 变换和 HHL 等量子算法。然而，在近期量子计算机上，还无法用足以体现这类优势的量子比特数实现这些算法。主要原因是：(i) 当前量子计算机所含的量子比特太少（如今约为数百个）；(ii) 它们执行的操作并不完美（含有噪声）。

此外，Shor 算法等算法必须经过编译才能在真实器件上运行。这意味着，作用于多个量子比特的幺正操作必须分解为实验平台能够实际实现的基本门。这种变换可能产生由原生门组成的复杂量子电路 [645]。例如，对 IBM-Q Washington 平台而言，只有 CNOT、ID、RZ、 $\sqrt{X}$ 和 X 门是原生门；其他任何门都必须分解为这些门。由于这些门构成一组通用量子门 [646]，理论上它们已经足够，但实践中却可能形成包含大量量子门的非常复杂的量子电路。例如，考虑把 Shor 算法分解为这些门的情形，如图 8.13 所示。一个看似简单的电路，在真实量子器件上实际上包含许多操作。由于物理器件中固有存在噪声和退相干，后一问题可能尤其严重。

¹³对于最小二乘支持向量机这一特殊情形，问题可以写成求解线性方程组。




图 8.13: 在真实量子计算机上实现著名的 Shor 算法. 左上图给出了该算法的简洁理论电路. 由于只能使用某些门 (CNOT 和 SWAP), 一般门必须分解, 因而电路需要更多量子门和更大的深度.

在现代量子计算机中, 可以辨认出三种主要误差来源: 门误差 (gate error) (由所需量子门施加得不精确而产生)、退相干误差 (decoherence error) (波函数的相干性随时间丧失) 和读出误差 (read-out error) (测量过程中对量子比特状态的错误读出)。

真实量子计算机中存在许多不同的噪声和误差来源, 因此我们距离容错量子计算 (fault-tolerant quantum computation) 还很远. 相反, 我们正处于所谓的含噪中等规模量子 (NISQ) 时代 [425]. 当前量子处理器的量子比特含有噪声, 并且需要量子纠错 (quantum error correction). 尽管如此, 研究这类系统的物理本身也很有趣. 特别地, 这一范围内可能存在具有量子加速的应用, 近期的量子优势实验便是一例 [629].

现在已经清楚, 我们无法在 NISQ 电路上运行需要大量量子门的算法, 也无法实现误差率很低的量子门. 如果电路包含的门过多, 相干性以及不同量子比特之间的叠加和纠缠就会丧失. 由此自然产生一个问题: 能否设计出在 NISQ 器件上表现良好、又不需要完全纠错量子计算的算法? 这意味着, 必须找到巧妙的方法, 在不使用精确算法的情况下探索指数庞大的 Hilbert 空间. 一种方案是利用量子计算机生成变分态, 并寻找迭代收敛到解的流程, 而不是沿直接的确定性路径求解 (例如, 可以在经典计算机上执行优化). 我们将在节 8.2.6 中更详细地介绍这些变分方案. 在此之前, 节 8.2.5 将说明如何把 NISQ 器件用于带核的 SVM.

总而言之, NISQ 时代的实验量子计算和量子纠错仍有许多开放问题. 截至 2024 年, 最先进的器件拥有 100+ 个物理量子比特, 误差率低于 0.2%¹⁴. 尽管如此, 近年来已经出现许多可以用近期器件完成的有用变分量子模拟, 例如见文献 [649]. 此外, 人们开发了许多量子误差缓解 (quantum error mitigation) 流程, 以减轻量子计算机中的噪声效应, 使人们能在近期从含噪器件中提取有用信息 [650, 651, 652, 653]. NISQ 器件也

¹⁴例如, 在 2024 年的随机电路采样实验 [647] 中, 作者报告超导量子比特的单量子比特门误差为 0.04%, 双量子比特门误差为 0.14%. 这些误差与近期中性原子量子处理单元所报告的误差处于同一数量级 [648].




图 8.14: 量子器件增强的量子支持向量机. (a) 量子核增强 SVM 各步骤的示意图. 数据被编码进量子电路等量子器件, 由器件计算核; 随后把这些核用于经典 SVM. (b) 文献 [654] 中用于展示量子核能力的数据集示例. 蓝色 (红色) 区域对应标签 1 (0) .

是一个极佳的试验场, 可用于在不构建容错量子计算机的情况下研究物理. 最后, 我们仍可能找到 NISQ 器件的有用应用, 并可将其视为迈向容错量子计算的一步.

8.2.5 带量子核的支持向量机

我们已经在节 8.2.3 中看到, 理想量子计算机可以通过实现 HHL 算法, 加速支持向量机 (SVM) 算法中数值代价高昂的部分. 其中的关键要素是利用量子计算机求解线性方程组. 2018 年, 三项独立工作 [655, 654, 656] 沿着另一条有趣的方向展开: 直接在量子器件上计算核, 而 SVM 算法的其余部分仍在经典计算机上执行.

这一思想示于图 8.14(a). 考虑一个线性不可分的数据集. 我们希望将其非线性嵌入更高维空间, 使数据在该空间中线性可分 (更多细节见节 4.2). 这里利用量子器件把经典数据 $\mathbf{x}$ 编码进高维 Hilbert 空间 $|\psi(\mathbf{x})\rangle$; 对文献 [655] 考虑的压缩态 (squeezed state), 该空间甚至是无限维的. 在这种情况下, 把经典态编码为量子态的方式至关重要, 因为它决定特征映射的质量. 更重要的是, 量子器件, 特别是量子电路, 可以高效计算两个量子态之间的标量积, 从而定义量子核

$$K_Q(\mathbf{x}_i, \mathbf{x}_j) = |\langle \psi(\mathbf{x}_i) | \psi(\mathbf{x}_j) \rangle|^2 = \sum_n \lambda_n \phi_n(\mathbf{x}_i) \phi_n(\mathbf{x}_j), \quad (8.20)$$

它具有带特征映射 ϕ 的经典核的全部性质, 并定义一个 RKHS (见节 4.1.3).¹⁵ 因此, 量子核可以直接用于核 PCA、核 SVM 或 Gaussian 过程等经典算法 [657], 从而使它们成为量子算法.

更具体地说, 下面说明文献 [654] 提出的量子核的主要构件. 给定由数据点 $\{\mathbf{x}_i\}$ 及其标签 $\{y_i\}$ 构成的数据集, 特征映射由可在量子比特电路中实现的么正变换 $U(\mathbf{x}_i)$ 定

¹⁵细心的读者可能会注意到, 式 8.20 是内积的模平方, 而非核通常采用的内积. 把核写成密度矩阵形式 $K_Q(\mathbf{x}_i, \mathbf{x}_j) = \text{Tr}(\rho_i \rho_j)$ 后, 这一点会更清楚. 此时, 该核对应于密度矩阵 ρ_i 与 ρ_j 的 Frobenius 内积 (Frobenius inner product) .

义：

$$\mathbf{x}_i \mapsto |\psi(\mathbf{x}_i)\rangle = U(\mathbf{x}_i) |0\rangle, \quad (8.21)$$

其中 $|0\rangle$ 表示乘积态 $|0\rangle^{\otimes n}$. 通常, 可以通过单量子比特的参数化局域旋转, 把经典数据编码进量子电路. 随后反复施加这些依赖数据的门和其他非参数化门 (例如纠缠门和 Hadamard 门), 从而构造么正操作. 这里不深入讨论电路构造的细节; 感兴趣的读者可以查阅相应的 Qiskit 教程 [658].

随后, 可以在量子电路上用计算-反计算技巧 (compute-uncompute trick) 计算量子核: 基本做法是实现量子电路 $U^\dagger(\mathbf{x}_j)U(\mathbf{x}_i)|0\rangle$, 并在 z 基中测量. 因此, 全零结果出现的频率给出核 $K_Q(\mathbf{x}_i, \mathbf{x}_j)$ 的估计.

得到这些核后, 可以在经典计算机上优化 SVM 的参数 (见节 4.2.2), 例如使用节 4.3 介绍的 Bayesian 优化 [657]. 文献 [654] 生成了一个复杂的分类问题, 如图 8.14(b) 所示, 其中蓝色 (红色) 区域对应标签 0 (1). 随后, 他们从这些区域中随机选点生成训练集, 并运行由量子核增强的 SVM. 对这一合成数据集, 该算法在测试集上取得了约 95% 的准确率.

上述例子表明, 量子核能够表示复杂数据集. 然而, 对一般数据集, 尚未观测到量子优势 [659, 660]. 文献 [633] 朝这一方向迈出了近期重要的一步: 作者构造了经典计算机无法高效分类的数据集; 文献 [661] 则利用随机化测量, 以改进的标度研究了量子计算机上的手写图像监督学习. 与此类似, 寻找构造量子核的最优方式 [662], 即如何执行输入编码 $\mathbf{x} \mapsto |\psi(\mathbf{x})\rangle$, 仍是一个活跃研究方向 [654]. 例如, 文献 [663] 以 Bayesian 信息准则 (BIC; 见节 4.4.1) 为选择度量, 为 SVM 算法构造量子核. 在所选分类问题上, 使用这种方式构造的量子核后, SVM 的性能显著高于采用常规核的已优化经典模型.

8.2.6 变分方法

本节讨论可在 NISQ 器件上实现的量子电路优化. 特别地, 这里聚焦于所谓的变分量子算法 (variational quantum algorithm). 这一思想推广了节 8.2.2 中介绍的玩具示例. 我们定义一个参数化量子电路 (parametrized quantum circuit) (PQC), 即依赖一组参数 $\{\theta\}$ 的电路 (例如, θ 可以是单量子比特旋转角). 随后定义一个希望最小化的目标函数 (objective function) $C(\theta)$. 这种目标函数总可以写成一组可观测量与 PQC 的函数. 我们的目标是找到使目标函数最小的最优参数组 θ^* . 这种变分方法可应用于许多领域, 例如机器学习 (分类、生成模型)、多体物理与量子化学 (寻找基态)、组合优化等.

我们以变分量子本征求解器 (VQE) [664] 为例, 说明变分方法的基本构件. 给定 Hamiltonian $\hat{H}$, VQE 的目标是使能量 $E = \langle \psi | \hat{H} | \psi \rangle$ 最小. VQE 的一般原理示于图 8.15. 该过程从一个易于在量子计算机上制备的初态开始, 例如乘积态 $|0\rangle^{\otimes n}$; 为简单起见, 将其记为 $|0\rangle$. 随后施加包含量子门全部参数 θ 的 PQC; 此时可把它视为制备量子态的黑箱. 第一次迭代中, 该状态只是一个随机态, 并被用作期望函数的初态; 除去一个全局相位, 该期望函数通常就是我们希望研究的物理系统的 Hamiltonian. Hamiltonian 可以描述分子或自旋系统中的相互作用; 更一般地, 它可以是以算符形式




图 8.15: 量子电路的变分优化，包括初态、PQC、输出、目标函数、测量和经典优化。

写出的任何代价函数，只要能在所用量子硬件的计算基中表示。下一步利用经典子程序最小化代价函数，以自洽方式在 PQC 可达的量子态空间中收敛到物理系统的最低能态。我们还知道，如果系统有能隙且基态唯一，那么 Hamiltonian 期望值的最小值就是基态能量，而相应本征值就是基态波函数。¹⁶

进一步具体来说，对 PQC，我们计算 Ansatz 的能量

$$E_0 = \min_{\theta} \langle\psi(\theta)|\hat{H}|\psi(\theta)\rangle = \min_{\theta} \langle 0|U^\dagger(\theta)\hat{H}U(\theta)|0\rangle.$$

其中， θ 是量子门的参数；对其进行优化，以最小化期望值。变分态是么正态，即把 PQC 施加于初态 $|0\rangle$ 所得的状态。然而，为了运行和使用 PQC，必须作出若干假设。第一，假设存在一组能够近似基态的参数，而且 PQC 可以表示这一特定解。第二，假设可以收敛到该解而不陷入局部极小值。最后，假设电路可以在 NISQ 计算机上运行。考虑所有这些假设后，设计 PQC 有两种方式。第一种是问题启发 Ansatz (problem-inspired ansatz)：当我们能够利用待表示系统的某些物理性质时，可以采用这种设计，例如像 VQE 算法那样，利用 Hamiltonian 表示设计么正操作。然而，这类 Ansatz 通常需要许多量子门或特定的量子比特连接关系，因此在当前量子计算机上无法用于较大的系统。另一种是硬件高效 Ansatz (hardware-efficient ansatz)；这是一种所需量子门少得多的启发式方法，其做法是制备一个使用原生门集合并遵守量子计算机连接关系的 PQC。一般而言，问题启发 Ansatz 往往更精确，却更难在当前量子计算机上实现；硬件高效 Ansatz 的情形则相反。

定义 PQC 后，下一步是选择目标函数。目标函数可以是把问题编码为量子算符的任何函数，例如图 8.15 所示的 Hamiltonian。随后把目标函数分解为 Pauli 串，因为可以用量子计算机测量各个 Pauli 串的期望值。测量流程是这一过程中的下一个重要步骤。在该步骤中，我们从量子计算机或量子器件中提取目标函数的值。这本身就是一项具有

¹⁶根据变分原理，每次迭代测得的能量都是基态能量的上界。当然，能否达到全局最小值取决于电路的表达能力。如果电路不包含该解，这种 Ansatz 就永远无法达到最低能量 [665]。




图 8.16: 变分量子模拟示例. (a) 模拟所用的参数化量子电路. (b) 优化算法运行期间的系统能量.

挑战性的任务，因为目标函数通常无法直接测量. 相反，要在量子硬件上计算 Pauli 串的期望值，就令波函数在相应 Pauli 基中坍缩. 从这项测量中，可以提取比特串 (bit string)，即由 0 和 1 组成的列表，例如 $[(0, 0, 1, 1, 0, 0), (1, 0, 1, 0, 0, 0), (0, 0, 1, 0, 1, 0)]$. 把各次 Pauli 测量得到的许多比特串组合起来，就能重构任何可写成 Pauli 矩阵张量积的目标函数的期望值. 如何寻找一种合适的测量策略，以尽可能少的比特串准确给出目标函数的值，仍是正在开展的研究 [666].

最后一步是经典优化；在这一步中，我们必须使用例如基于梯度的方法在 PQC 参数空间中搜索. 梯度可以写成量子电路关于某个参数的导数的期望值，而我们无法直接访问量子态的梯度. 在 NISQ 器件中，可以用参数移位规则 (parameter shift rule) 计算 PQC 的梯度 [667]：对每个参数 θ ，只需对两个 PQC 求值，就能精确计算其偏导数.¹⁷ 这一步的问题在于所需测量的次数. 为了运行经典最小化算法，需要测量所有梯度. 因此，这种方法可能非常昂贵：它包含大量变量，并且需要多次迭代才能收敛到基态；这正是人们还会采用遗传算法或强化学习策略等无梯度方法的原因. 总之，把量子电路的变分优化与经典优化算法结合起来，是利用 NISQ 器件解决现实问题的一种高效方式.

下面讨论一个具体例子，即作用于四个自旋的 Heisenberg Hamiltonian：

$$\hat{H} = \sum_{i=1}^3 (J_1 \sigma_i^x \sigma_{i+1}^x + J_2 \sigma_i^y \sigma_{i+1}^y + J_3 \sigma_i^z \sigma_{i+1}^z) + \sum_{i=1}^4 (h_1 \sigma_i^x + h_2 \sigma_i^y + h_3 \sigma_i^z). \quad (8.22)$$

我们把 Hamiltonian 的参数固定为 $\mathbf{J} = [1, 1, -1]$ 和 $\mathbf{h} = [1, 1.5, 3]$. 选择这些参数是为了远离任何相变点，以免问题过于困难. 可以用这个 Hamiltonian 作为算法的基准. 对四量子比特情形，再考虑一个非常简单的量子 Ansatz. 该 Ansatz 包含沿 Y 和 Z 方向施加于每个量子比特的两个旋转门、连接所有量子比特的三个 CNOT 门，以及沿 Y 和 Z 方向的另外两个旋转门. 电路示于图 8.16(a).

在变分量子本征求解器 (VQE) 中，我们希望用变分电路使系统能量最小. 如果在

¹⁷相比之下，由于存在反向模式微分（也称反向传播），计算经典神经网络损失的梯度只需对模型求值一次；见节 2.5.

经典计算机上执行这一操作，能量求值的计算成本会随量子比特数呈指数增长。在理想量子计算机上，可以高效计算系统 Hamiltonian 的期望值，其计算成本随量子比特数线性增长。我们可以把这个代价函数交给优化器；这里采用 Nelder-Mead 优化程序。在图 8.16(b) 中，我们绘出了系统能量随优化步数的变化。只用少量变分参数，并付出关于量子比特数呈多项式增长的计算成本，就能得到相当好的基态能量近似。这类模拟在变分 Ansatz 的设计和优化程序两方面都有许多可改进之处。例如，在设计变分量子电路时，可以施加所研究系统的对称性。在优化程序中，可以使用 SGD 等基于梯度的方法，也可以使用节 4.3 介绍的贝叶斯优化等无梯度方法。例如，文献 [230] 的作者推导出一种受参数移位规则启发的新核，以更少的量子计算机测量次数准确更新 VQE 参数。更多细节见节 4.5.4。

8.2.7 用于量子机器学习的参数化量子电路

变分量子电路可用于对经典数据进行分类。构造这类量子算法时，第一个非平凡任务是把经典数据加载到量子硬件上。此外，算法必须能够高效处理这些数据，并具备执行分类的方法。文献 [668] 的作者表明，采用数据重上传 (data reuploading) 的 PQC 可以成为良好的分类器。文献 [669] 的作者引入了量子卷积神经网络 (quantum convolutional neural network) 的概念。与经典 CNN 类似，这些变分量子电路具有更大的容量。特别地，作者说明了如何直接从量子态出发，利用这些电路对 Haldane 链中的对称性保护拓扑相 (symmetry-protected topological phase) 进行分类；该量子态可由 VQE 得到。这一思想已在近期工作中得到实验实现 [634]。此外，值得注意的是，上述分类器与量子核密切相关 [670, 671]。最后，文献 [672] 的作者开发了一种循环量子神经网络 (recurrent quantum neural network)，并将其用于手写数字的分类与生成。

在量子强化学习 (quantum reinforcement learning) 中，PQC 还可用于实现行动价值函数，或直接实现强化学习策略（关于 Q-learning 和深度 Q-learning，见节 6.2；关于策略梯度的介绍，见节 6.3）。文献 [673, 674] 给出了两个在强化学习语境下利用 PQC 的算法示例。在文献 [673] 中，量子电路使用策略梯度算法训练，并用于求解经典环境，即寻找当前任务的最优策略。所选行动及我们希望确定的该行动发生概率，将编码在所测量的可观测量中——如果有一组给定的行动，就定义一组相应的可观测量。这种强化学习架构规定，智能体观测电路将产生的量子态，而相应可观测量的期望值将编码 $\pi(a | s)$ ，即在给定强化学习状态 s 下采取行动 a 的概率；换言之，它对应于策略 π 。在文献 [674] 中，作者把 OpenAI Gym [675] 中的示例用作深度 Q-learning 变分量子算法的基准环境，例如 Cartpole 游戏（小车可以左右移动，智能体试图让连接在小车上的杆保持平衡）。与经典模型（这些示例环境原本正是为其创建的）相比，量子模型可以用少得多的参数达到相近的准确率；这一点本身并不意味着模型更好，但突出了两者的差异。一个有趣的开放问题是，这些结果能否推广到其他环境。

与其经典对应物的思路相同（见节 2.4.5），量子自动编码器 (quantum autoencoder) [676] 用于在量子计算机上压缩量子数据。量子自动编码器直接作用于编码在量子比特中的数据，因此无需获得代价呈指数增长的经典表示，就能压缩量子数据。由于存在经典

计算无法生成的模式，例如纠缠，量子版本的自动编码器或许能够识别超出经典能力的模式。量子自动编码器所做的编码把量子数据变换到量子比特数更少的潜空间中。给定一组编码到 n 个量子比特中的量子数据，我们希望在由 $k = n - p$ 个量子比特构成的潜空间中找到该 n 量子比特态的表示。这 p 个量子比特称为垃圾量子比特 (trash qubit)。

这种编码通过一个变分映射实现；该映射由参数数目为多项式量级的量子电路 $U(\theta)$ 表示。由于编码过程是么正操作（量子电路），解码算符就由 $U^\dagger(\theta)$ 的 Hermitian 共轭表示。这种量子算法相对于其经典对应物是否具有计算优势，仍存在争议。人们还提出了用于多种应用的变分量子自动编码器，例如量子数据去噪 [677]、相分类 [124]、Hilbert 空间聚类 [125] 或量子纠错 [678]。

生成模型是学习数据集分布的算法。在量子力学中，器件内禀的量子性质对于学习概率分布，特别是量子波函数，可以提供很大帮助。近期，人们提出了多种 QML 架构，包括基于量子 Hamiltonian 的模型 [679]、量子 GAN [680, 681] 和量子 Born 机 (quantum Born machine) [682, 683, 684]。特别地，量子电路 Born 机 (quantum circuit Born machine) 是能够表示经典数据分布的生成模型；这些分布表示为纯量子态。在此语境下，变分量子电路可以为表示这些概率分布提供一种有用工具，并且还能提供从这些分布高效采样的方法。该算法的性能与其经典对应物相当。文献 [684] 的作者还提出了另一种量子电路 Born 机，它能够学习相干热态 (coherent thermal state) 的概率分布，其中概率分布由 Boltzmann 权重给出。这类算法可以在 NISQ 器件上运行，是近期实现量子优势的良好候选方案。

8.2.8 当前的实验与理论局限

在最后这一小节中，我们讨论为了成功应用和使用 NISQ 器件而必须克服的一些实验与理论开放问题。一个重要主题是量子误差缓解，即减少或补偿误差。这既包括经典后处理技术，也包括直接在硬件上进行的主动操作。前一种途径包括基于稳定子方法 (stabilizer-based approach)，它依赖与自旋或粒子数等守恒量相关的信息 [685]；还包括基于数据经典后处理的缓解方案 [650, 651, 652, 653]。不过，这些方法都只是在电路运行之后使用的后处理工具。另一类误差缓解方法是主动缓解技术 (active mitigation technique) 或量子最优控制策略。与后处理技术不同，这些方法直接涉及实验和量子硬件 [686, 687, 688, 689, 690, 691]。

我们面对的不仅是实验开放问题，还有必须解决或克服的理论开放问题。其中之一是贫瘠高原问题 (barren-plateau problem) [692]；它出现在以局域么正操作参数化的量子电路之全局代价函数中。在没有关于解的先验知识时，PQC 的参数 θ 会被随机初始化。其结果是出现贫瘠高原：梯度期望值和方差期望值都会随量子比特数和/或电路深度指数消失。换言之，损失景观大部分是平坦的，只有一条容纳全局极小值的狭窄沟谷 [693]。贫瘠高原问题的可能解决方案包括：使用接近解的参数，以局域代价函数代替全局代价函数，或在参数之间引入关联 [692, 693]。后两类方案的缺点是，它们对强关联系统效果不佳。贫瘠高原问题的一般解仍是开放的理论问题。此外，目前完全不清楚是否存在任何自然问题，使 PQC 能够胜过经典学习引擎 [671]。

损失景观的另一个特征，是会出现许多可能远离全局极小值的局域极小值 [694]。经

典神经网络的训练中也存在类似情形 [43]——这一现象是否会给 PQC 的实际应用带来真正的挑战，仍是开放问题。

另一个理论障碍涉及 PQC 的容量。设置 PQC Ansatz 时，必须小心避免把 PQC 可达的 Hilbert 空间限制得过窄。否则，我们可能落入 Hilbert 空间中的错误区域，无法得到解的良好近似 [695, 665]。虽然存在一些度量（例如 Haar 分布 (Haar distribution)），但 PQC Ansatz 的容量仍是开放问题。然而，即使事先知道适合给定任务的 Ansatz 类，仅仅优化其超参数（例如电路深度）也已是一项困难任务；换言之，存在这样的具体问题：我们不能指望在优化后找到哪怕近似良好的解 [696]。

电路编译 (circuit compilation) 是另一个重要挑战，兼有理论与实验部分：理论电路、分解为原生门、简化，最终再映射到硬件和真实量子比特系统。电路编译依赖 Solovay–Kitaev 定理 (Solovay–Kitaev theorem) [697, 646]；该定理指出，使用一组通用门，可以用多项式深度的电路把任意 $SU(N)$ 近似到一定精度。不过，在具体硬件实现中，有些门比另一些门更容易控制。在 PQC 中，人们总是尽量多用原生门。这种方案可以使量子电路更短、更简单。

最后，大量工作已经投入具有量子优势的应用，也就是量子计算机比经典对应物使用更少资源的应用。研究这类算法至关重要，并且很可能需要把量子器件集成进高性能计算设施。

展望与开放问题

我们目前处于 NISQ 时代。尽管走向容错量子计算面临复杂的理论与实验挑战，NISQ 时代的总体目标仍是了解能够在当前实验平台上实现的算法。降低影响量子比特的错误率并提升量子门效率是一项艰巨任务，需要基础科学与技术进步；与此同时，还需要开发用于控制量子计算机的软件工具，发展误差缓解技术并制定量子最优控制策略，以及开发刻画变分量子算法的工具，例如研究损失景观 [491, 698]、纠缠性质 [699] 等。此外，开发能够利用量子计算机、却没有直接经典对应物的算法，是超越 CQ 范式 (CQ paradigm) 的一个非常有趣但也富有挑战的方向。

延伸阅读

- Biamonte, J. *et al.* (2017). *Quantum machine learning*. Nature **549**, 195. 这是量子机器学习主题的一篇非常著名的综述。
- Bharti, K. *et al.* (2022). *Noisy intermediate-scale quantum (NISQ) algorithms*. Rev. Mod. Phys. **94**, 015004. 这是一篇聚焦 NISQ 时代变分量子电路模拟的综述论文。
- Li, W. & Deng, D.-L. (2022). *Recent advances for quantum classifiers*. Sci. China: Phys. Mech. Astron. **65**, 220301. 这是一篇关于量子计算机分类算法的近期综述论文。
- Cerezo, M. *et al.* (2021). *Variational quantum algorithms*. Nat. Rev. Phys. **3**, 625. 这是一篇介绍变分量子算法及其应用近期进展的优秀综述论文。

- 关于量子机器学习的 [Qiskit 教程](#).
- 关于量子机器学习的 [PennyLane 教程与演示](#).
- 关于量子强化学习的 [Tensorflow Quantum 教程](#).

结论与展望

过去十年间，机器学习（尤其是深度学习）得到了深入研究，并给计算机视觉、自然语言处理等许多领域带来了革命性变化。

这一领域带来的新工具箱与新思想也已成功应用于科学研究。特别地，无论在经典还是量子情形下，机器学习和深度学习都已被用于处理物理科学与化学科学中的问题。其应用范围涵盖粒子物理、流体动力学、宇宙学、多体量子系统 [4, 5, 6]，乃至量子计算和量子信息理论 [700]。另一方面，物理学家已开始应用统计物理学工具，尝试理解与深度学习训练相关的动力学 [585]，并且也在探索基于量子物理的潜在硬件 [701]。

本书旨在向物理学家和化学家介绍机器学习中的若干选题，以及它们在物理学和化学中的一些应用。由于这一领域相对年轻且发展迅速，我们决定重点向具有物理或化学背景的科学家解释机器学习中的关键概念，并简要回顾若干可能的应用。我们还讨论了物理学如何帮助人们更深入地理解支配深度学习的内在机制，以及如何将量子技术用于数据驱动任务。当然，本书涵盖的主题和应用并非详尽无遗。尽管如此，我们希望已经传达了自己对于将机器学习应用于量子科学的热情，也希望已经恰当地介绍了热心读者深入这一领域所需的基本构件。

最后，我们总结本书探索的方向，并分享我们对潜在精彩进展的看法。需要指出的是，这些看法形成于 2022 年；因此，我们非常好奇，它们能否在读者手中经受住时间的检验。

轨迹与相的表征和分类。 研究者已深入研究多种机器学习和深度学习方法，以处理轨迹与相的表征和分类。尽管其中许多技术取得了巨大成功 [6, 702]，仍有许多挑战尚待解决。大多数工作都侧重于用监督学习方案复现已知相图。处理无标签数据并应用无监督学习或自监督学习的能力，是帮助物理学家发现新奇物态的一大进步。此外，由于最强大的模型都是黑箱，可解释性技术对于帮助物理学家发现这些模型学到的相关物理概念至关重要。例如，文献 [149, 156] 能够从轨迹中发现物理概念或恢复守恒律。另一个非常有趣的方向，是直接从实验数据对相进行分类 [140, 143, 703, 106, 141, 704]，尤其是在分类结果还伴有相应序参量信息时。理解实验噪声相对于模拟数据会如何影响分类，同样值得研究。

高斯过程与核方法。 高斯过程和基于核的回归方法都是机器学习算法；由于其计算成本随训练数据集大小呈三次标度，人们认为它们不适用于高维系统 [241]。尽管如此，事实证明，基于核的方法是稳健的回归工具，其准确率可与深度学习方法媲美，同时没有超参数优化这一限制。得益于贝叶斯优化的成功，它们在优化领域也发挥了重要作用 [182]。基于核的方法主要围绕两项挑战取得进展：(i) 矩阵求逆的数值程序；(ii) 更稳健的核函数。图形处理器（GPU）的兴起推动了基于核方法的高效算法发展（例如 GPyTorch [236]）。基于核方法的准确率取决于底层核函数的学习能力。尽管类似贝叶斯信息准则的算法已被证明很适合构造契合数据的核，但自动微分的兴起以及按照文

献 [234] 的思路参数化更复杂核的能力, 也提供了令人振奋的替代方向. 最后, 基于核的方法还被扩展到分子系统: 以基于字符串的比较作为核函数 [705], 以及用于计算 Fock 态之间的相似度 [706].

神经网络量子态. 用神经网络表示多体波函数, 在预测体系基态性质 (例如能量) 方面似乎非常成功; 对于 $J_1 - J_2$ 模型, 其表现甚至超过了最先进的投影纠缠对态 (PEPS) 技术 [707]. 人们也对用神经网络量子态研究多体波函数的时间演化抱有浓厚兴趣 [287, 708, 283], 在高于一维的体系中尤其如此. 当前的挑战包括把神经网络量子态推广到混合态 (例如开放量子系统), 以及在神经网络量子态中实现对称性. 人们尤其关注寻找把神经网络量子态推广到费米子体系的策略. 此外, 把神经网络量子态用于连续空间中相互作用电子的从头算研究, 是量子化学与量子物理中一个很有前景的方向 [294, 293]. 另一个有趣方向, 是更深入地理解神经网络量子态的内部结构与容量 [709]. 最后, 把神经网络量子态用于量子态重构也是一个非常活跃的领域.

强化学习. 强化学习为量子技术的发展提供了一个强大的框架, 具有广泛的应用. 人们正不断努力把强化学习技术与实验装置结合起来, 由此开辟了多种研究途径.

一个有趣方向是对量子模拟器进行实时控制 [441, 710, 447]; 这或许能让我们制备并研究超出当前能力范围的复杂物相. 类似地, 我们可以用基于强化学习的控制提升含噪中等规模量子器件, 向容错量子计算迈进 [422, 431, 442, 711].

另一个可能的方向是借助强化学习设计实验平台, 从而发现开展量子实验的新方法. 在文献 [375] 中, 作者发现了能够制备高度纠缠量子态的新型光学装置. 类似地, 我们还可以探索新的量子计算架构, 或者设计新的技术器件.

在更偏理论的层面, 强化学习是一种强大的优化工具, 可以单独使用, 也可以与其他成熟技术结合, 用来帮助我们求解富有挑战性的问题 [440].

一个值得关注的总体方向是衔接理论与实验进展; 为此, 例如可以利用强化学习设计具有所需性质的 Hamiltonian [712].

可微编程. 可微编程在物理学中的应用可能大有裨益. 它可以用于多种技术, 例如变分 Monte Carlo (关于神经网络量子态, 见章 5)、张量网络 [462] 或平均场 [467]. 这些工作表明, 此类算法既能免去计算导数这一繁琐环节, 又能保持最先进水平结果. 把自动微分整合到求解微分方程等其他任务中, 同样很有前景.

用于科学发现的机器学习. 人工智能能够进行科学发现和科学理解吗? 在科学中使用机器学习带来的希望与前景极其广阔, 但迄今能够称为“科学发现”的成果仍然很少. 特别是, DeepMind 的 AlphaFold 算法 [713, 714] 仅根据蛋白质的遗传序列便能预测其三维结构 (即所谓蛋白质折叠问题), 因而可能真正给生物学和医学带来革命性变化. 自动化实验室和自主实验室能够改变我们开展实验的方式 [576]. 人工智能还可能满足对量子器件进行可扩展、高效验证, 以及验证其底层物理 Hamiltonian 的迫切需求.

另一个例子是文献 [143] 提出的、由机器学习引导的预先构造假设选择. 作者首先用来自两种不同理论的数值数据训练模型; 这两种理论都被假设为所研究物理体系的底层理论. 随后, 他们让模型判断哪种理论能更好地描述该体系的实验快照. 一种令人振奋的方法, 是用机器学习引导科学家进入问题中值得关注的参数区; 相分类 [126]、数学 [715] 和量子信息 [716, 717] 领域都已有这样的实践. 最后需要指出, 即使存在一个能够预测任何过程结果的全知预言机, 它也不会先验地赋予我们科学理解, 更不能证明我们具有科学理解 [40]. 这再次指向机器学习可解释性这一关键挑战.

用于机器学习的统计物理学. 统计力学与物理学家的视角有助于阐明机器学习的内部工作机制. 来自无序系统物理学的计算方法, 以及对学习问题的教师-学生建模, 已经成为研究现代机器学习核心谜题——过参数化模型的泛化——的一种强大范式 [614, 615]. 与此同时, 可以用这些相同的方法 [616, 620] 以及 Langevin 方程 [625] 研究学习动力学. 统计力学工具也能为改进机器学习架构的训练提供很大帮助. 这一方向的近期工作采用物理方法, 改进了受限 Boltzmann 机的训练 [718, 626]. Gardner 方案与教师-学生范式都已成功用于研究量子架构的容量 [621, 623, 622] 以及量子神经网络的泛化 [624].

基于物理过程的潜在硬件加速器. 如今, 神经网络运行在经典器件上. 尽管过去十年间图形处理器 (GPU) 已成为这一领域的变革性力量, 但当前神经网络架构所用的内存、计算时间与能量都在不断增长, 最终将成为瓶颈. 因此, 人们正投入大量努力, 寻找在物理器件中实现神经网络的新型器件 [719]. 这一研究方向的主要目标, 是构建神经网络的物理实现, 以执行完全并行的高速运算. 这类平台的例子包括神经网络的光学实现 [720, 721, 722, 723, 724, 725, 726, 727] 和激子-极化激元 (exciton-polariton) [728, 729, 730, 731, 732]. 另一方向已在节 8.2 中讨论: 利用经典-量子混合器件执行数据驱动任务. 这一方向的关键问题, 是把量子器件集成到高性能计算设施中. 最后, 近期工作还探索了另一个方向, 重新回到经典机器学习早期的思想: 设计 Hopfield 网络的量子推广 [733, 734].

致谢

我们感谢 Hans J. Briegel、Lorenzo Cardarelli、Kacper Cybiński 和 Mario Krenn 所作的有益讨论，并感谢 Fesido Studio Graficzne 承担本书的图形设计。

作者贡献 本手稿源自一次独特合作，参与者包括 2021 年 8–9 月在波兰华沙举办的量子物理与化学中的机器学习暑期学校的学员与讲师；该暑期学校由 M. Tomza、A. Dauphin、A. Dawid 和 M. Lewenstein 组织。本手稿的所有作者都参与了内容的阅读与改进。具体而言：

- “引言”由 A. Dawid 撰写，M. Płodzień、M. Lewenstein、A. Gresch、R. Koch、B. Requena 和 G. Muñoz-Gil 提供协助。
- “机器学习基础”由 A. Dawid、A. Gresch 和 J. Arnold 撰写，K. Nicoli、K. Donatella 和 M. Płodzień 提供协助。
- “相分类”由 J. Arnold、A. Dawid、A. Gresch、R. Koch、M. Płodzień 和 S. Wetzel 撰写，科学内容由 E. Greplová、P. Huembeli 和 S. Wetzel 提供。
- “高斯过程与其他核方法”由 A. Gresch、A. Dawid、K. Nicoli、J. Arnold、R. Krems 和 R. A. Vargas-Hernández 撰写，科学内容由 R. Krems 提供。
- “神经网络量子态”由 K. Donatella、B. Requena 和 P. Stornati 撰写，R. Okuła 和 M. Płodzień 提供协助，科学内容由 G. Carleo、J. Carrasquilla 和 F. Vicentini 提供。
- “强化学习”由 B. Requena、M. Płodzień 和 A. Gresch 撰写，R. Okuła 和 G. Muñoz-Gil 提供协助，科学内容由 V. Dunjko、F. Marquardt 和 E. van Nieuwenburg 提供。
- “可微编程”由 J. Arnold 撰写；“多体物理中的生成模型”由 K. A. Nicoli 和 M. Gabrié 撰写，M. Płodzień、K. Donatella 和 A. Dawid 提供协助；“实验中的机器学习”由 M. Büttner、R. Koch 和 A. Dawid 撰写。这些部分所依据的科学内容由 J. Carrasquilla、E. Greplová 和 L. Wang 提供。
- “用于机器学习的统计物理学”由 A. Dawid 撰写，M. Płodzień 提供协助，其科学内容来自 M. Gabrié；“量子机器学习”由 P. Stornati、A. Dauphin、M. Płodzień 和 R. Koch 撰写，R. Okuła 提供协助，其内容基于 A. Cervera-Liarta 和 V. Dunjko 的课程。
- 最后，“结论与展望”由 A. Dauphin、B. Requena、M. Płodzień 和 A. Dawid 撰写，所有合著者均提供了协助。

本项目由 A. Dawid 领导, 并由 A. Dauphin 在 M. Lewenstein 和 M. Tomza 的协助下指导.

资助信息 An.D. 感谢波兰国家科学中心通过 Preludium 项目 (编号 2019/33/N/ST2/03123) 和 Etiuda 项目 (编号 2020/36/T/ST2/00588) 提供的资助, 并感谢波兰科学基金会的资助. Flatiron Institute 是 Simons Foundation 的一个部门.

J.A. 感谢瑞士国家科学基金会个人项目 (项目编号 200020 200481) 的资助.

A.G. 感谢德国研究基金会 (Deutsche Forschungsgemeinschaft, DFG) 的资助, 项目编号 441423094.

M.P. 感谢波兰国家学术交流署 Bekker 计划 (编号 PPN/BEK/2020/1/00317) 的支持.

K.A.N. 感谢德国联邦教育与研究部 (BMBF) 对 Berlin Institute for the Foundations of Learning and Data (BIFOLD) 的支持 (01IS18037A) .

R.K. 感谢芬兰科学院项目 (编号 331342 和 336243) 的资助.

G.M-G. 感谢奥地利科学基金 (FWF) 通过 SFB BeyondC F7102 提供的支持.

A.C-L. 感谢西班牙政府经济事务与数字化转型部通过 QUANTUM ENIA 项目征集的 QUANTUM SPAIN 项目提供的支持, 并感谢欧盟在 Digital Spain 2025 Agenda 框架下通过 Recovery, Transformation and Resilience Plan-NextGenerationEU 提供的支持.

M.G. 感谢其作为 Hi!Paris 讲席持有人的资助.

L.W. 获得中国科学院战略性先导科技专项 (编号 XDB30000000) 和国家自然科学基金 (编号 T2121001) 的支持.

M.T. 感谢波兰科学基金会在欧盟区域发展基金共同资助的 First Team 计划下提供的资助.

Al.D. 感谢 la Caixa Foundation 提供的研究员资助 (ID 100010434, 资助代码 LCF/BQ/PR20/11770012) .

本项目获得了欧盟 Horizon 2020 研究与创新计划在 Marie Skłodowska-Curie 资助协议 (编号 895439, “ConQuER”) 下提供的资助.

ICFO 团队感谢以下各方的支持: ERC AdG NOQIA; MICIN/AEI (PGC2018-0910.13039/501100011033, CEX2019-000910-S/10.13039/501100011033, Plan National FIDEUA PID2019-106901GB-I00, FPI; MICIN, 资金来自 European Union NextGenerationEU (PRTR-C17.I1) : QUANTERA MAQS PCI2019-111828-2); MICIN/AEI/10.13039/501100011033, 以及 “European Union NextGeneration EU/PRTR” 资助的 QUANTERA DYNAMITE PCI2022-132919 (QuantERA II Programme, 由欧盟 Horizon 2020 计划根据资助协议编号 101017733 共同资助); 西班牙政府经济事务与数字化转型部通过 QUANTUM ENIA 项目征集的 Quantum Spain 项目提供的支持, 以及欧盟在 Digital Spain 2026 Agenda 框架下通过 Recovery, Transformation and Resilience Plan-NextGenerationEU 提供的支持; Fundació Cellex; Fundació Mir-Puig; Generalitat de Catalunya (European Social Fund FEDER and CERCA program, AGAUR Grant No. 2021 SGR 01452, QuantumCAT U16-011424, 由 ERDF Operational Program of Catalonia 2014-2020 共同资助); Barcelona Supercomputing Center MareNostrum (FI-2023-1-0013); EU Quantum Flagship (PASQuanS2.1, 101113690); EU Horizon 2020 FET-OPEN OPTologic (Grant No. 899794); EU Horizon Europe Program (Grant Agreement 101080086—NeQST); 波兰国家科学中心 (Symfonia Grant No. 2016/20/W/ST4/00314); ICFO 内部 “QuantumGaudi” 项目; “La Caixa” Junior Leaders fellowships ID100010434: LCF/BQ/PI19/11690013, LCF/BQ/PI20/11760031, LCF/BQ/PR20/11770012, LCF/BQ/PR21/11840013. 然而, 所表达的观点和意见仅代表作者本人, 并不必然反映欧盟、European Commission、European Climate, Infrastructure and Environment Executive Agency (CINEA) 或任何其他资助机构的观点和意见. 欧盟及任何资助机构均不对此承担责任.

Perimeter Institute 的研究部分由加拿大政府通过 Department of Innovation, Science and Economic Development Canada 提供支持, 并由安大略省通过 Ministry of Economic Development, Job Creation and Trade 提供支持. 我们感谢 National Research Council of Canada 与 Perimeter 在 PIQuIL 项目上的合作.

主成分分析的数学细节

我们可以从两种不同的视角来说明 PCA 的动机. 第一种已在正文中概述, 其出发点是在降低数据维数时保留尽可能大的数据方差, 因此对应一个约束最大化问题. 也可以把 PCA 看作这样一种算法: 它寻找设计矩阵 $\mathbf{X}$ 的低秩近似 $\mathbf{Z}$, 使两个矩阵之间的距离在相差一个投影 $\mathbf{V}$ 的意义下最小. 我们将证明这两种途径等价. 也就是说, 投影矩阵 $\mathbf{V}$ 是下式的解:

$$\mathbf{V} = \underbrace{\arg \min_{\mathbf{V}'} \min_{\mathbf{Z}} \frac{1}{n} \|\mathbf{X} - \mathbf{V}' \mathbf{Z}\|^2}_{\text{高维空间中的最小误差}} = \underbrace{\arg \max_{\mathbf{V}'} \frac{1}{n} \|\mathbf{V}'^\top \mathbf{X}\|^2}_{\text{低维空间中的最大方差}}. \quad (\text{A.1})$$

由于这里处理的是矩阵, 范数指 Frobenius 范数 $\|\mathbf{A}\|^2 := \text{tr}[\mathbf{A}^\top \mathbf{A}]$.

先回顾正文采用的途径, 即式 (A.1) 右侧的方差最大化. 我们将 n 个 m 维数据点堆叠起来定义设计矩阵 $\mathbf{X}$. 不过, 为了便于数学证明, 这里把它定义为转置后的 $(m \times n)$ 矩阵. 假设数据均值为零, 我们构造经验协方差矩阵 $\Sigma = (\mathbf{X} \mathbf{X}^\top)/n = \Sigma^\top$; 它包含任意两个输入特征之间的全部协方差. 我们希望找到一个能保留数据最大方差的线性变换 $\mathbf{V}$.

由于假设数据均值为零, 投影数据 $\mathbf{V}^\top \mathbf{X}$ 的均值也为零. 输入数据的经验方差为 $\sum_{i=1}^n \mathbf{x}_i^2/n$. 我们希望迭代地找出投影矩阵的各列. $\mathbf{V}$ 的第一列 $\mathbf{v}_1$ 通过最大化方差 $\sum_{i=1}^n (\mathbf{v}_1^\top \mathbf{x}_i)^2/n$ 得到. 这可归结为如下优化问题:

$$\max_{\mathbf{v}_1} \frac{1}{n} \|\mathbf{v}_1^\top \mathbf{X}\|^2 = \max_{\mathbf{v}_1} \frac{1}{n} \mathbf{v}_1^\top \mathbf{X} \mathbf{X}^\top \mathbf{v}_1 = \max_{\mathbf{v}_1} \mathbf{v}_1^\top \Sigma \mathbf{v}_1, \quad \text{s.t. } \mathbf{v}_1^\top \mathbf{v}_1 = 1. \quad (\text{A.2})$$

该约束保证最大值为有限值; 这里还代入了向量范数和协方差矩阵的定义. 我们用 Lagrange 乘子法求解这一约束优化问题. 为此, 定义 Lagrangian $\mathcal{L}(\mathbf{v}_1) = \mathbf{v}_1^\top \Sigma \mathbf{v}_1 - \mu_1(\mathbf{v}_1^\top \mathbf{v}_1 - 1)$, 其微分为 $d\mathcal{L} = 2(\mathbf{v}_1^\top \Sigma - \mu_1 \mathbf{v}_1^\top) d\mathbf{v}_1$. 最优解要求 $d\mathcal{L} = 0$. 当 $\Sigma \mathbf{v}_1 = \mu_1 \mathbf{v}_1$ 时, 这一条件成立. 由此识别出本征值问题: $\mathbf{v}_1$ 必须是 Σ 的本征矢, 其本征值为 μ_1 . 于是, 取 μ_1 为 Σ 的最大本征值 λ_1 即可使目标最大化.

对于 $\mathbf{V}$ 的下一列 $\mathbf{v}_2$, 我们从式 (A.2) 出发, 并加入约束 $\mathbf{v}_1^\top \mathbf{v}_2 = 0$, 以保证 $\mathbf{v}_1$ 与 $\mathbf{v}_2$ 正交. 写出修改后的 Lagrangian, 并计算它关于 $d\mathbf{v}_2$ 的微分, 得到条件 $2\Sigma \mathbf{v}_2 - 2\mu_2 \mathbf{v}_2 - \kappa \mathbf{v}_1 = 0$, 其中 κ 是正交约束的 Lagrange 乘子. 从左侧用 $\mathbf{v}_1^\top$ 乘等式两边并应用正交条件, 得到 $\kappa = 0$. 将其代回上一条件, 再次得到 $\Sigma \mathbf{v}_2 = \mu_2 \mathbf{v}_2$. 与此前相同的推理表明, μ_2 必须是 Σ 的第二大本征值 λ_2 , 相应本征矢为 $\mathbf{v}_2$. 迭代进行, 就能把 $\mathbf{V}$ 的其余列确定为 Σ 的其余本征矢, 并按本征值排序.

现在我们理解了正文所述步骤的依据, 也理解了为何可以舍弃承载方差最小的本征矢来实现降维. 降维后的数据在各坐标轴上的方差由相应主成分决定. 还可以把投影设计矩阵改为 $\mathbf{X}_{\text{white}} = \Lambda^{-1/2} \mathbf{V}^\top \mathbf{X}$, 使每条坐标轴上的方差都变为单位方差; 这一操作

称为数据的白化 (whitening). 这里, $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots)$ 是由 Σ 的 k 个最大本征值按降序组成的对角矩阵. 为验证这一点, 考虑本征值分解 $\mathbf{X}\mathbf{X}^\top/n = \mathbf{V}\Lambda\mathbf{V}^\top$, 其中 $\mathbf{V}^\top\mathbf{V} = \mathbf{1} = \mathbf{V}\mathbf{V}^\top$. 重新整理各项可得 $\Lambda^{-1/2}\mathbf{V}^\top\mathbf{X}\mathbf{X}^\top\mathbf{V}\Lambda^{-1/2} = n\mathbf{1}$, 因此 $\mathbf{X}_{\text{white}}$ 的相应协方差矩阵为单位矩阵.

如式 (A.1) 所示, 还可以通过最小化设计矩阵 $\mathbf{X}$ 与其低秩重构 $\mathbf{Z}$ 之间的近似误差, 以另一种等价方式求得 $\mathbf{V}$. 两个矩阵在相差投影 $\mathbf{V}$ 意义下的均方误差由如下约束优化问题给出:

$$\min_{\mathbf{V}, \mathbf{Z}} \|\mathbf{X} - \mathbf{V}\mathbf{Z}\|^2 = \min_{\mathbf{V}, \mathbf{Z}} \text{tr}[(\mathbf{X} - \mathbf{V}\mathbf{Z})^\top(\mathbf{X} - \mathbf{V}\mathbf{Z})], \quad \text{s.t. } \mathbf{V}^\top\mathbf{V} = \mathbf{1}. \quad (\text{A.3})$$

这里代入了 Frobenius 范数的定义. 施加该约束不失一般性: 假设 $\mathbf{V}^\top\mathbf{V} = \mathbf{A} \neq \mathbf{1}$. 考虑 $\mathbf{A}$ 的本征值分解 $\mathbf{A} = \mathbf{W}\Lambda\mathbf{W}^\top$, 其中 $\mathbf{W}^\top\mathbf{W} = \mathbf{1}$. 因而 $\mathbf{V}^\top\mathbf{V} = \mathbf{A} = \mathbf{W}\Lambda\mathbf{W}^\top \Rightarrow \Lambda = (\mathbf{V}\mathbf{W})^\top(\mathbf{V}\mathbf{W})$; 令 $\tilde{\mathbf{V}} = \Lambda^{-1/2}\mathbf{V}\mathbf{W}$ 并转而对 $\tilde{\mathbf{V}}$ 最小化, 就恢复了所需约束.

我们仍用 Lagrange 乘子求解. 不过, 现在的约束是矩阵约束, 因此引入矩阵值 Lagrange 乘子 $\mathbf{M}^\top$. 由于矩阵间距离由 Frobenius 范数给出, Lagrangian 为

$$\mathcal{L}(\mathbf{V}, \mathbf{Z}) = \text{tr}[(\mathbf{X} - \mathbf{V}\mathbf{Z})^\top(\mathbf{X} - \mathbf{V}\mathbf{Z})] - \text{tr}[\mathbf{M}(\mathbf{V}^\top\mathbf{V} - \mathbf{1})].$$

利用矩阵微积分, 其微分为 $d\mathcal{L} = -2\text{tr}[(\mathbf{X} - \mathbf{V}\mathbf{Z})^\top\mathbf{V}d\mathbf{Z}]$. 令其为零, 要求 $\mathbf{X}^\top\mathbf{V} = \mathbf{Z}^\top\mathbf{V}^\top\mathbf{V} = \mathbf{Z}^\top$, 从而 $\mathbf{Z} = \mathbf{V}^\top\mathbf{X}$. 将其代入目标可得 $\text{tr}[(\mathbf{X} - \mathbf{V}\mathbf{Z})^\top(\mathbf{X} - \mathbf{V}\mathbf{Z})] = \text{tr}[\mathbf{X}^\top\mathbf{X} - \mathbf{X}^\top\mathbf{V}\mathbf{V}^\top\mathbf{X}]$. 第一项与最小化参数 $\mathbf{V}$ 无关, 因而可以舍去. 第二项可改写为 $-\|\mathbf{V}^\top\mathbf{X}\|$; 吸收负号后, 最小化就转化为最大化 $\|\mathbf{V}^\top\mathbf{X}\|$. 这恰好是式 (A.2) 中方差最大化原理的目标, 因此两者等价.

在上述推导中, 我们没有讨论 Lagrange 乘子 $\mathbf{M}$ 如何消失. 其论证与前文类似, 需要考虑 $\mathbf{M}$ 的本征值分解. 这实际上只会给 $\mathbf{V}$ 增加一个旋转, 而该旋转仍可通过重新定义 $\mathbf{V}$ 吸收. 最后说明第二种推导的一个推论: 只选取与最大本征值相对应的 $k \ll n$ 个本征矢 $(\mathbf{v}_i)_i$ 来组成 $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_k]$, 即可得到设计矩阵 $\mathbf{X}$ 的适当低秩近似. 这样可保证在 $k = n$ 时近似误差消失. 由此得到近似 $\mathbf{X} \approx \mathbf{V}\mathbf{V}^\top\mathbf{X}$, 从而论证了第 3.2.1 节算法 2 所述步骤的合理性.

核技巧的推导

这里给出核技巧的推导. 训练数据 $\mathcal{D} = \{(\mathbf{X}, \mathbf{y})\}$ 定义为

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,m} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \cdots & x_{n,m} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}. \quad (\text{B.1})$$

其中, $\mathbf{X}$ 的每一行 (即 $\mathbf{x}_i$) 都是与观测量 y_i 关联的一个数据点, n 是数据点数, m 是特征数. 考虑第 2.4.1 节中的线性模型 $f(\mathbf{x}, \boldsymbol{\theta}) = \mathbf{x}^\top \boldsymbol{\theta}$. 在岭回归中, 损失函数为

$$\begin{aligned} \mathcal{L}(\boldsymbol{\theta}, \mathbf{X}, \mathbf{y}) &= \|f(\mathbf{X}, \boldsymbol{\theta}) - \mathbf{y}\|_2^2 + \lambda \|\boldsymbol{\theta}\|_2^2 \\ &= \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|_2^2 + \lambda \|\boldsymbol{\theta}\|_2^2. \end{aligned} \quad (\text{B.2})$$

这里 $\|\cdot\|_2$ 表示 ℓ_2 范数. 对 $\boldsymbol{\theta}$ 最小化 $\mathcal{L}(\boldsymbol{\theta}, \mathbf{X}, \mathbf{y})$, 得到最优参数集 $\boldsymbol{\theta}^*$:

$$\begin{aligned} \boldsymbol{\theta}^* &= \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}, \mathbf{X}, \mathbf{y}) \\ &= \arg \min_{\boldsymbol{\theta}} \{ \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|_2^2 + \lambda \|\boldsymbol{\theta}\|_2^2 \}. \end{aligned} \quad (\text{B.3})$$

要验证 $\boldsymbol{\theta}^*$ 是 $\mathcal{L}$ 的最优解, 可以检查 $\nabla_{\boldsymbol{\theta}} \mathcal{L}|_{\boldsymbol{\theta}^*} = \mathbf{0}$. 由于 f 对 $\boldsymbol{\theta}$ 具有线性依赖, $\nabla_{\boldsymbol{\theta}} \mathcal{L}$ 有闭式解. 在继续推导之前, 先展开式 (B.2):

$$\begin{aligned} \mathcal{L}(\boldsymbol{\theta}, \mathbf{X}, \mathbf{y}) &= (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^\top (\mathbf{X}\boldsymbol{\theta} - \mathbf{y}) + \lambda \boldsymbol{\theta}^\top \boldsymbol{\theta} \\ &= \boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - \boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{X} \boldsymbol{\theta} + \mathbf{y}^\top \mathbf{y} + \lambda \boldsymbol{\theta}^\top \boldsymbol{\theta}. \end{aligned} \quad (\text{B.4})$$

令 $\mathcal{L}$ 关于 $\boldsymbol{\theta}$ 的梯度为零来求 $\boldsymbol{\theta}^*$, 得到

$$\nabla_{\boldsymbol{\theta}} \mathcal{L} = \mathbf{0} = 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - 2\mathbf{X}^\top \mathbf{y} + 2\lambda \boldsymbol{\theta}. \quad (\text{B.5})$$

推导式 (B.5) 所需的求导恒等式可参见文献 [735]. 解出 $\boldsymbol{\theta}$, 可得

$$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{1}) \boldsymbol{\theta} = \mathbf{X}^\top \mathbf{y}, \quad (\text{B.6})$$

其中

$$\boldsymbol{\theta}^* = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{1})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (\text{B.7})$$

在进一步推导前，考察 $\mathbf{X}^\top \mathbf{X}$ 项：

$$\begin{aligned}\mathbf{X}^\top \mathbf{X} &= \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{bmatrix} \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \\ &= \begin{bmatrix} x_{1,1} & \cdots & x_{n,1} \\ x_{1,2} & \cdots & x_{n,2} \\ \vdots & \ddots & \vdots \\ x_{1,m} & \cdots & x_{n,m} \end{bmatrix} \begin{bmatrix} x_{1,1} & \cdots & x_{1,m} \\ x_{2,1} & \cdots & x_{2,m} \\ \vdots & \ddots & \vdots \\ x_{n,1} & \cdots & x_{n,m} \end{bmatrix}.\end{aligned}\quad (\text{B.8})$$

这里 $\mathbf{X}^\top \mathbf{X}$ 是一个 $(m \times m)$ 矩阵，其矩阵元表示“数据点数”空间中的点积。最优解 $\boldsymbol{\theta}^*$ 还可改写为

$$\boldsymbol{\theta}^* = \mathbf{X}^\top (\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{1})^{-1} \mathbf{y}, \quad (\text{B.9})$$

其中使用了如下矩阵恒等式 [735]：

$$(\mathbf{A} \mathbf{B} + \mathbf{1})^{-1} \mathbf{A} = \mathbf{A} (\mathbf{B} \mathbf{A} + \mathbf{1})^{-1}. \quad (\text{B.10})$$

类似地，考察 $\mathbf{X} \mathbf{X}^\top$ 项：

$$\mathbf{X} \mathbf{X}^\top = \begin{bmatrix} x_{1,1} & \cdots & x_{1,m} \\ x_{2,1} & \cdots & x_{2,m} \\ \vdots & \ddots & \vdots \\ x_{n,1} & \cdots & x_{n,m} \end{bmatrix} \begin{bmatrix} x_{1,1} & \cdots & x_{n,1} \\ x_{1,2} & \cdots & x_{n,2} \\ \vdots & \ddots & \vdots \\ x_{1,m} & \cdots & x_{n,m} \end{bmatrix}. \quad (\text{B.11})$$

可以看到，此时的矩阵元表示两个训练数据点之间的标准点积 $\mathbf{x}_i^\top \mathbf{x}_j$ 。使用式 (B.9) 的一个缺点是，当 $n \gg m$ 时，对 $n \times n$ 矩阵 $\mathbf{X} \mathbf{X}^\top$ 求逆的计算代价会更高。

用式 (B.10) 将式 (B.7) 中的 $\boldsymbol{\theta}^*$ 改写为式 (B.9) 后，对新点 $\mathbf{x}_{\text{new}}$ 的预测变为

$$\begin{aligned}f(\mathbf{x}_{\text{new}}, \boldsymbol{\theta}^*) &= (\boldsymbol{\theta}^*)^\top \mathbf{x}_{\text{new}} = \mathbf{x}_{\text{new}}^\top \boldsymbol{\theta}^* \\ &= \underbrace{\mathbf{x}_{\text{new}}^\top \mathbf{X}^\top}_{\text{核}} \underbrace{(\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{1})^{-1} \mathbf{y}}_{\text{参数}}.\end{aligned}\quad (\text{B.12})$$

其中， $(\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{1})^{-1} \mathbf{y}$ 表示模型的最优参数，而 $\mathbf{x}_{\text{new}}^\top \mathbf{X}^\top$ 是 $\mathbf{x}_{\text{new}}$ 在训练数据特征空间中的表示。对线性模型， $\mathbf{x}_{\text{new}}^\top \mathbf{X}^\top$ 由函数求值点与训练数据之间的点积计算：

$$\begin{aligned}\mathbf{x}_{\text{new}}^\top \mathbf{X}^\top &= \begin{bmatrix} x_1^{\text{new}} & x_2^{\text{new}} & \cdots & x_m^{\text{new}} \end{bmatrix} \begin{bmatrix} x_{1,1} & \cdots & x_{n,1} \\ x_{1,2} & \cdots & x_{n,2} \\ \vdots & \ddots & \vdots \\ x_{1,m} & \cdots & x_{n,m} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{x}_{\text{new}}^\top \mathbf{x}_1 \\ \mathbf{x}_{\text{new}}^\top \mathbf{x}_2 \\ \vdots \\ \mathbf{x}_{\text{new}}^\top \mathbf{x}_n \end{bmatrix}^\top.\end{aligned}\quad (\text{B.13})$$

由式 (B.12) 和式 (B.13) 可见, 可以在 $\{\mathbf{x}_{\text{new}}^\top \mathbf{x}_i\}_{i=1}^n$ 特征空间上定义第二个线性模型:

$$f(\mathbf{x}_{\text{new}}, \tilde{\boldsymbol{\theta}}^*) = (\tilde{\boldsymbol{\theta}}^*)^\top (\mathbf{X} \mathbf{x}_{\text{new}}), \quad (\text{B.14})$$

其中 $\tilde{\boldsymbol{\theta}}^* = (\mathbf{X} \mathbf{X}^\top + \lambda \mathbf{1})^{-1} \mathbf{y}$ 是一个 n 维向量.

最初考虑的是 $\mathbf{x}$ 上的线性模型 $f(\mathbf{x}, \boldsymbol{\theta}) = \mathbf{x}^\top \boldsymbol{\theta}$. 不过, 也可以考虑由基函数集 $\Phi = [\phi_0, \phi_1, \dots, \phi_\ell]$ 张成的另一特征空间上的线性模型. 若在推导中以 $\Phi(\mathbf{x}) = [\phi_0(\mathbf{x}), \phi_1(\mathbf{x}), \dots, \phi_\ell(\mathbf{x})]$ 代替 $\mathbf{x}$, 即把数据变换到相应特征空间, 则式 (B.12) 推广为

$$\begin{aligned} f(\Phi(\mathbf{x}_{\text{new}}), \boldsymbol{\theta}^*) &= (\boldsymbol{\theta}^*)^\top \Phi(\mathbf{x}_{\text{new}}) = \Phi(\mathbf{x}_{\text{new}})^\top \boldsymbol{\theta}^* \\ &= \Phi(\mathbf{x}_{\text{new}})^\top \Phi(\mathbf{X})^\top (\Phi(\mathbf{X}) \Phi(\mathbf{X})^\top + \lambda \mathbf{1})^{-1} \mathbf{y}. \end{aligned} \quad (\text{B.15})$$

这里, $\Phi(\mathbf{x}_{\text{new}})^\top \Phi(\mathbf{X})^\top$ 对应 $\mathbf{x}_{\text{new}}$ 与训练数据 $\mathbf{X}$ 在基函数展开中的点积. 此外, $\Phi(\mathbf{X}) \Phi(\mathbf{X})^\top$ 对应所有训练数据点两两之间在基函数展开中的点积, 即 $[\Phi(\mathbf{X}) \Phi(\mathbf{X})^\top]_{ij} = \Phi(\mathbf{x}_i)^\top \Phi(\mathbf{x}_j)$.

在核方法语境中, $\Phi(\mathbf{X}) \Phi(\mathbf{X})^\top$ 称为设计矩阵 $\mathbf{K}$. 需要强调的是, $f(\Phi(\mathbf{x}_{\text{new}}), \boldsymbol{\theta}^*)$ 的计算对基函数展开的依赖仅通过点积 $\Phi(\mathbf{x}_i)^\top \Phi(\mathbf{x}_j)$ 出现. 这便实现了第 4.1 节所述的核技巧. 最后, 虽然以上推导针对 KRR, 但 GP 的对数似然 (式 (4.42)) 具有相同的代数形式. 因此, 该推导也说明了 GP 模型如何通过核来运作.

将核矩阵选作高斯过程的协方差矩阵

在高斯过程回归 (GPR) 中, 协方差函数至关重要, 因为它编码了我们对待学习目标函数或影响目标值的噪声所作的某些先验假设. 第 4 节已经讨论过如何用核函数表示 GP 的协方差函数. 在这一语境下, 数据点之间的相似性概念非常重要, 而核是把数据邻近性概念纳入回归器协方差函数的最合适工具. 因此, 可以把 GP 先验的协方差选为核函数 K 给出的核矩阵 $\mathbf{K}$:

$$\text{Cov}(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j). \quad (\text{C.1})$$

这将取代最初对参数所选的 Gaussian 先验 (见式 (4.41)):

$$p_{\text{prior}}(\boldsymbol{\theta}) = \mathcal{N}(0, \boldsymbol{\Sigma}_{m+1}). \quad (\text{C.2})$$

为说明这一点, 从式 (2.23) 的线性模型出发, 利用特征映射 ϕ 把输入 $\mathbf{x}$ 映射到特征空间, 使得

$$f(\mathbf{x}) = \phi(\mathbf{x})^\top \boldsymbol{\theta}. \quad (\text{C.3})$$

对参数 $\boldsymbol{\theta}$ 取期望可得

$$\mathbb{E}[f(\mathbf{x})] = \phi(\mathbf{x})^\top \mathbb{E}[\boldsymbol{\theta}] = 0. \quad (\text{C.4})$$

利用这一结果, 协方差可写为

$$\begin{aligned} \text{Cov}(\mathbf{x}_i, \mathbf{x}_j) &= \mathbb{E}[f(\mathbf{x}_i)f(\mathbf{x}_j)] \\ &= \phi(\mathbf{x}_i)^\top \mathbb{E}[\boldsymbol{\theta}\boldsymbol{\theta}^\top] \phi(\mathbf{x}_j) \\ &= \phi(\mathbf{x}_i)^\top \boldsymbol{\Sigma}_{m+1} \phi(\mathbf{x}_j) \\ &= \phi'(\mathbf{x}_i)^\top \phi'(\mathbf{x}_j). \end{aligned} \quad (\text{C.5})$$

最后一步利用了 $\boldsymbol{\Sigma}_{m+1}$ 的本征值分解 $\boldsymbol{\Sigma}_{m+1} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^\top$, 由此可定义 $\phi'(\mathbf{x}) := \boldsymbol{\Lambda}^{1/2}\mathbf{U}^\top\phi(\mathbf{x})$. 因此, 可以对协方差矩阵应用核技巧, 并像式 (C.1) 那样将其提升为核矩阵 $\mathbf{K}$. 联立式 (C.4) 和式 (C.5), 便回到式 (C.2) 的同一形式.

我们的目标是计算边际似然

$$p(\mathbf{y} | \mathbf{X}) = \int_{\mathbb{R}^{m+1}} p(\mathbf{y} | \boldsymbol{\theta}, \mathbf{X}) p(\boldsymbol{\theta} | \mathbf{X}) d\boldsymbol{\theta}. \quad (\text{C.6})$$

所谓边际似然，是指对模型参数 $\boldsymbol{\theta}$ 作边缘化，即计算式 (C.6) 中的积分。很快将看到，边际似然可以用核矩阵表示。在 GP 模型下，先验是零均值 Gaussian，其方差现由核矩阵 $\mathbf{K}$ 给出，即 $\boldsymbol{\theta} | \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \mathbf{K})$ 。先验的对数可写为

$$\begin{aligned} \log p(\boldsymbol{\theta} | \mathbf{X}) &= \log \left[\frac{\exp(-\frac{1}{2} \boldsymbol{\theta}^\top \mathbf{K}^{-1} \boldsymbol{\theta})}{\sqrt{(2\pi)^n |\mathbf{K}|}} \right] \\ &= -\frac{1}{2} \boldsymbol{\theta}^\top \mathbf{K}^{-1} \boldsymbol{\theta} - \frac{1}{2} \log |\mathbf{K}| - \frac{n}{2} \log 2\pi. \end{aligned} \quad (\text{C.7})$$

这里 $|\mathbf{K}|$ 表示 $\mathbf{K}$ 的行列式。

似然是式 (C.6) 被积函数中的第一项；由于它是满足 $\mathbf{y} | \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}, \sigma^2 \mathbf{1})$ 的因子化 Gaussian，被积函数化为两个 Gaussian 的乘积，因而其本身也是 Gaussian，可以直接应用两个 Gaussian 乘积的熟知关系。具体而言，对于两个 Gaussian 分布 $\mathcal{N}(\mathbf{a}, \mathbf{A})$ 和 $\mathcal{N}(\mathbf{b}, \mathbf{B})$ ，有

$$\mathcal{N}(\mathbf{a}, \mathbf{A}) \mathcal{N}(\mathbf{b}, \mathbf{B}) = Z^{-1} \mathcal{N}(\mathbf{c}, \mathbf{C}). \quad (\text{C.8})$$

其中 $\mathbf{c} = \mathbf{C}(\mathbf{A}^{-1}\mathbf{a} + \mathbf{B}^{-1}\mathbf{b})$ ，且 $\mathbf{C} = (\mathbf{A}^{-1} + \mathbf{B}^{-1})^{-1}$ 。上式中，矩阵 $\{\mathbf{A}, \mathbf{B}\}$ 表示两个 Gaussian 的方差，而 $\{\mathbf{a}, \mathbf{b}\}$ 是相应均值。因此，所得 Gaussian 的方差等于两个逆方差之和的逆，其均值等于由精度矩阵（方差的逆）加权的均值凸组合。归一化常数 Z^{-1} 本身也具有类似 Gaussian 的形式：

$$Z^{-1} = (2\pi)^{-n/2} |\mathbf{A} + \mathbf{B}|^{-1/2} \exp \left[-\frac{1}{2} (\mathbf{a} - \mathbf{b})^\top (\mathbf{A} + \mathbf{B})^{-1} (\mathbf{a} - \mathbf{b}) \right]. \quad (\text{C.9})$$

利用这一结果，可以完成式 (C.6) 中的积分；更多细节和证明参见文献 [241]。为把式 (C.8) 和式 (C.9) 的结果用于当前问题，式 (C.8) 中的均值集合 $\{\mathbf{a}, \mathbf{b}\}$ 和方差集合 $\{\mathbf{A}, \mathbf{B}\}$ 分别取为 $\{\boldsymbol{\theta}, \mathbf{0}\}$ 和 $\{\sigma^2 \mathbf{1}, \mathbf{K}\}$ 。继续推导，得到边际似然的闭式解：

$$\log p(\mathbf{y} | \mathbf{X}) = -\frac{1}{2} \mathbf{y}^\top (\mathbf{K} + \sigma^2 \mathbf{1})^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K} + \sigma^2 \mathbf{1}| - \frac{n}{2} \log 2\pi. \quad (\text{C.10})$$

为完整起见，还应指出，只需注意到 $\mathbf{y} | \mathbf{X} \sim \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma^2 \mathbf{1})$ ，也可得到同一结果。总之，GP 的训练归结为寻找核函数 K 的参数，使式 (4.60) 中的边缘对数似然最大化。

参考文献

- [1] B. Blaiszik, *blaiszik/ml_publication_charts: AI/ML Publication Statistics for 2022*, doi:10.5281/zenodo.7713954 (2023).
- [2] Summer School: Machine Learning in Science and Technology, [GitHub repository](#) with selected tutorials from the school (2021).
- [3] A. Dawid, J. Arnold, B. Requena, A. Gresch, M. Płodzień, K. Donatella, K. Nicoli, P. Stornati, R. Koch, M. Büttner, R. Okuła, G. Muñoz-Gil *et al.*, [GitHub repository](#) with figures prepared for these Lecture Notes, doi:10.5281/zenodo.13959927 (2022).
- [4] V. Dunjko and H. J. Briegel, *Machine learning & artificial intelligence in the quantum domain: a review of recent progress*, Rep. Prog. Phys. **81**(7), 074001 (2018), doi:10.1088/1361-6633/aab406.
- [5] G. Carleo, I. Cirac, K. Cranmer, L. Daudet, M. Schuld, N. Tishby, L. Vogt-Maranto and L. Zdeborová, *Machine learning and the physical sciences*, Rev. Mod. Phys. **91**, 045002 (2019), doi:10.1103/RevModPhys.91.045002.
- [6] J. Carrasquilla, *Machine learning for quantum matter*, Adv. Phys.: X **5**(1), 1797528 (2020), doi:10.1080/23746149.2020.1797528.
- [7] C. Williams, *A brief introduction to artificial intelligence*, In *Proceedings OCEANS '83*, pp. 94–99, doi:10.1109/OCEANS.1983.1152096 (1983).
- [8] R. Dearden and C. Boutilier, *Abstraction and approximate decision-theoretic planning*, Artif. Intell. **89**(1), 219 (1997), doi:10.1016/S0004-3702(96)00023-9.
- [9] J.-D. Zucker, *A grounded theory of abstraction in artificial intelligence*, Phil. Trans. R. Soc. Lond. B **358**(1435), 1293 (2003), doi:10.1098/rstb.2003.1308.
- [10] L. Saitta and J.-D. Zucker, *Abstraction in Artificial Intelligence and Complex Systems*, Springer, New York, NY, ISBN 978-1-4614-7051-9, doi:10.1007/978-1-4614-7052-6 (2013).
- [11] M. Mitchell, *Abstraction and analogy-making in artificial intelligence*, Ann. N. Y. Acad. Sci. **1505**(1), 79 (2021), doi:10.1111/nyas.14619.
- [12] H. Moravec, *Mind Children: The Future of Robot and Human Intelligence*, Harvard University Press, Cambridge, Massachusetts, ISBN 0674576160, doi:10.2307/1575314, P. 15 (1988).
- [13] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*, The MIT Press, ISBN 0262035618 (2016).

- [14] G. Marcus, *Deep learning is hitting a wall*, [Nautilus](#), Accessed: 2022-03-11 (2022).
- [15] T. J. Sejnowski, *The Deep Learning Revolution: Machine Intelligence Meets Human Intelligence*, The MIT Press, ISBN 9780262038034, doi:10.7551/mitpress/11474.001.0001 (2018).
- [16] Y. LeCun, Y. Bengio and G. Hinton, *Deep learning*, *Nature* **521**(7553), 436 (2015), doi:10.1038/nature14539.
- [17] J. Schmidhuber, *Deep learning in neural networks: An overview*, *Neural Netw.* **61**, 85 (2015), doi:10.1016/j.neunet.2014.09.003.
- [18] G. E. Hinton, S. Osindero and Y.-W. Teh, *A fast learning algorithm for deep belief nets*, *Neural Comput.* **18**(7), 1527 (2006), doi:10.1162/neco.2006.18.7.1527.
- [19] V. Volkov and J. W. Demmel, *Benchmarking GPUs to tune dense linear algebra*, In *SC '08: Proceedings of the 2008 ACM/IEEE Conference on Supercomputing*, pp. 1–11, doi:10.1109/SC.2008.5214359 (2008).
- [20] R. Raina, A. Madhavan and A. Y. Ng, *Large-scale deep unsupervised learning using graphics processors*, In *Proceedings of the 26th Annual International Conference on Machine Learning*, ICML '09, p. 873–880. Association for Computing Machinery, New York, NY, USA, ISBN 9781605585161, doi:10.1145/1553374.1553486 (2009).
- [21] B. Marr, *How much data do we create every day? The mind-blowing stats everyone should read*, [Forbes](#), Accessed: 2018-05-21 (2018).
- [22] SeedScientific, *Volume of data/information created, captured, copied, and consumed worldwide from 2010 to 2025*, [SeedScientific](#), Accessed: 2022-01-28 (2021).
- [23] Statista Research Department, *Volume of data/information created, captured, copied, and consumed worldwide from 2010 to 2025*, [Statista](#), Accessed: 2022-03-18 (2022).
- [24] A. Dawid and Y. LeCun, *Introduction to latent variable energy-based models: a path toward autonomous machine intelligence*, *J. Stat. Mech.* **2024**(10), 104011 (2024), doi:10.1088/1742-5468/ad292b.
- [25] M. F. Dixon, I. Halperin and P. Bilokon, *Machine Learning in Finance: From Theory to Practice*, Springer, ISBN 9783030410674, doi:10.1007/978-3-030-41068-1 (2020).
- [26] J. Eisenstein, *Introduction to Natural Language Processing*, The MIT Press, ISBN 9780262042840 (2019).

- [27] S. Polu, J. M. Han, K. Zheng, M. Baksys, I. Babuschkin and I. Sutskever, *Formal mathematics statement curriculum learning*, In *ICLR 2023 - Int. Conf. Learn. Represent.* (2023), [arXiv:2202.01344](https://arxiv.org/abs/2202.01344).
- [28] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie *et al.*, *Human-level control through deep reinforcement learning*, *Nature* **518**(7540), 529 (2015), doi:10.1038/nature14236.
- [29] O. Vinyals, I. Babuschkin, W. M. Czarnecki, M. Mathieu, A. Dudzik, J. Chung, D. H. Choi, R. Powell, T. Ewalds, P. Georgiev, J. Oh, D. Horgan *et al.*, *Grand-master level in StarCraft II using multi-agent reinforcement learning*, *Nature* **575**(7782), 350 (2019), doi:10.1038/s41586-019-1724-z.
- [30] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. van den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, S. Dieleman, D. Grewe *et al.*, *Mastering the game of Go with deep neural networks and tree search*, *Nature* **529**(7587), 484 (2016), doi:10.1038/nature16961.
- [31] Y. Lecun, L. Bottou, Y. Bengio and P. Haffner, *Gradient-based learning applied to document recognition*, *Proc. IEEE* **86**(11), 2278 (1998), doi:10.1109/5.726791.
- [32] R. A. Fisher, *The use of multiple measurements in taxonomic problems*, *Ann. Eug.* **7**, 179 (1936), doi:10.1111/j.1469-1809.1936.tb02137.x.
- [33] A. Krizhevsky, *Learning multiple layers of features from tiny images*, Tech. rep., MIT & NYU, [CiteSeer^X 10.1.1.222.9220](https://arxiv.org/abs/1206.5808) (2009).
- [34] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg and L. Fei-Fei, *ImageNet large scale visual recognition challenge*, *Int. J. Comput. Vis.* **115**(3), 211 (2015), doi:10.1007/s11263-015-0816-y.
- [35] D. Gissin, *Active learning review*, [GitHub.io](https://github.com/dgissin/active-learning-review), Accessed: 2022-04-08 (2020).
- [36] P. Ren, Y. Xiao, X. Chang, P.-Y. Huang, Z. Li, B. B. Gupta, X. Chen and X. Wang, *A survey of deep active learning*, *ACM Comput. Surv.* **54**(9) (2021), doi:10.1145/3472291.
- [37] J. E. van Engelen and H. H. Hoos, *A survey on semi-supervised learning*, *Mach. Learn.* **109**(2), 373 (2020), doi:10.1007/s10994-019-05855-6.
- [38] M. Krenn, J. Landgraf, T. Foessel and F. Marquardt, *Artificial intelligence and machine learning for quantum technologies*, *Phys. Rev. A* **107**, 010101 (2023), doi:10.1103/PhysRevA.107.010101.

- [39] F. Chollet, *On the measure of intelligence* (2019), [arXiv:1911.01547](#).
- [40] M. Krenn, R. Pollice, S. Y. Guo, M. Aldeghi, A. Cervera-Lierta, P. Friederich, G. dos Passos Gomes, F. Häse, A. Jinich, A. Nigam, Z. Yao and A. Aspuru-Guzik, *On scientific understanding with artificial intelligence*, *Nat. Rev. Phys.* **4**, 761–(2022), doi:10.1038/s42254-022-00518-3.
- [41] R. Bagheri, *Weight initialization in deep neural networks*, [Towards Data Science](#), Accessed: 2022-02-16 (2020).
- [42] T. Akiba, S. Sano, T. Yanase, T. Ohta and M. Koyama, *Optuna: A next-generation hyperparameter optimization framework*, In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, KDD '19, p. 2623–2631. Association for Computing Machinery, New York, NY, USA, ISBN 9781450362016, doi:10.1145/3292500.3330701 (2019).
- [43] A. L. Blum and R. L. Rivest, *Training a 3-node neural network is NP-complete*, *Neural Netw.* **5**(1), 117 (1992), doi:10.1016/S0893-6080(05)80010-3.
- [44] H. Li, Z. Xu, G. Taylor, C. Studer and T. Goldstein, *Visualizing the loss landscape of neural nets*, In *NeurIPS 2018 - Adv. Neural Inf. Process. Syst.* (2018), [arXiv:1712.09913](#).
- [45] L. Bottou, *Large-Scale Machine Learning with Stochastic Gradient Descent*, In Y. Lechevallier and G. Saporta, eds., *Proceedings of COMPSTAT'2010*, pp. 177–186. Physica-Verlag HD, Heidelberg, ISBN 978-3-7908-2604-3, doi:10.1007/978-3-7908-2604-3_16 (2010).
- [46] Y. Feng and Y. Tu, *The inverse variance–flatness relation in stochastic gradient descent is critical for finding flat minima*, *Proc. Natl. Acad. Sci. U.S.A.* **118**(9) (2021), doi:10.1073/pnas.2015617118.
- [47] J. D. Lee, M. Simchowitz, M. I. Jordan and B. Recht, *Gradient descent only converges to minimizers*, In V. Feldman, A. Rakhlin and O. Shamir, eds., *29th Annual Conference on Learning Theory*, vol. 49 of *Proceedings of Machine Learning Research*, pp. 1246–1257. PMLR, Columbia University, New York, New York, USA (2016), [arXiv:1602.04915](#).
- [48] A. Choromanska, M. Henaff, M. Mathieu, G. Ben Arous and Y. LeCun, *The loss surfaces of multilayer networks*, In *AISTATS 2015 - Int. Conf. Artif. Intell. Stat.*, vol. 38, pp. 192–204. PMLR (2015), [arXiv:1412.0233](#).
- [49] Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli and Y. Bengio, *Identifying and attacking the saddle point problem in high-dimensional non-convex optimization*, In *NIPS 2014 - Adv. Neural Inf. Process. Syst.* (2014), [arXiv:1406.2572](#).

- [50] L. Sagun, L. Bottou and Y. LeCun, *Eigenvalues of the Hessian in deep learning: singularity and beyond* (2016), [arXiv:1611.07476](#).
- [51] G. Alain, N. Le Roux and P. A. Manzagol, *Negative eigenvalues of the Hessian in deep neural networks*, In *ICLR 2018 - Int. Conf. Learn. Represent.* (2018), [arXiv:1902.02366](#).
- [52] I. Sutskever, J. Martens, G. Dahl and G. Hinton, *On the importance of initialization and momentum in deep learning*, In *ICML 2013 - 30th Int. Conf. Mach. Learn.*, vol. 28, pp. 1139–1147 (2013).
- [53] Y. Liu, Y. Gao and W. Yin, *An improved analysis of stochastic gradient descent with momentum*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2007.07989](#).
- [54] J. Duchi, E. Hazan and Y. Singer, *Adaptive subgradient methods for online learning and stochastic optimization*, *J. Mach. Learn. Res.* **12**, 2121–2159 (2011), doi:10.5555/1953048.2021068.
- [55] D. P. Kingma and J. Ba, *Adam: A method for stochastic optimization*, In *ICLR 2015 - Int. Conf. Learn. Represent.* (2015), [arXiv:1412.6980](#).
- [56] Z. Zhang, *Improved Adam optimizer for deep neural networks*, In *2018 IEEE/ACM 26th Int. Symp. Qual. Serv. IWQoS 2018*, pp. 1–2, doi:10.1109/IWQoS.2018.8624183 (2018).
- [57] C. Zhu, R. H. Byrd, P. Lu and J. Nocedal, *Algorithm 778: L-BFGS-B*, *ACM Trans. Math. Softw.* **23**(4), 550 (1997), doi:10.1145/279232.279236.
- [58] L. M. Rios and N. V. Sahinidis, *Derivative-free optimization: A review of algorithms and comparison of software implementations*, *J. Glob. Optim.* **56**(3), 1247 (2012), doi:10.1007/s10898-012-9951-y.
- [59] W. Liu, X. Wang, J. Owens and Y. Li, *Energy-based out-of-distribution detection*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2010.03759](#).
- [60] C. Zhang, S. Bengio, M. Hardt, B. Recht and O. Vinyals, *Understanding deep learning requires rethinking generalization*, In *ICLR 2017 - Int. Conf. Learn. Represent.* (2017), [arXiv:1611.03530](#).
- [61] D. H. Wolpert, *What Is Important About the No Free Lunch Theorems?*, pp. 373–388, Springer International Publishing, ISBN 978-3-030-66515-9, doi:10.1007/978-3-030-66515-9_13 (2021).
- [62] P. Domingos, *A unified bias-variance decomposition for zero-one and squared loss*, In *NCAI 2000 - 17th National Conference on Artificial Intelligence*, pp. 564–569, ISBN 0262511126 (2000).

- [63] M. Belkin, D. Hsu, S. Ma and S. Mandal, *Reconciling modern machine-learning practice and the classical bias–variance trade-off*, Proc. Natl. Acad. Sci. U.S.A. **116**(32), 15849 (2019), doi:10.1073/pnas.1903070116.
- [64] K. Kawaguchi, L. P. Kaelbling and Y. Bengio, *Generalization in deep learning*, In *Mathematical Aspects of Deep Learning*. Cambridge University Press, doi: 10.1017/9781009025096.003 (2022).
- [65] J. Frankle and M. Carbin, *The lottery ticket hypothesis: Finding sparse, trainable neural networks*, In *ICLR 2019 - Int. Conf. Learn. Represent.* (2019), [arXiv:1803.03635](#).
- [66] L. Devroye, L. Györfi and G. Lugosi, *The Bayes Error*, pp. 9–20, Springer, New York, NY, ISBN 978-1-4612-0711-5, doi:10.1007/978-1-4612-0711-5_2 (1996).
- [67] C. R. Rao, *Generalized inverse of a matrix and its applications*, pp. 601–620, University of California Press, doi:10.1525/9780520325883-032 (1972).
- [68] R. Tibshirani, *Regression shrinkage and selection via the lasso*, J. R. Stat. Soc. Ser. B Methodol. **58**(1), 267 (1996), doi:10.1111/j.2517-6161.1996.tb02080.x.
- [69] Z. Zhou, X. Li and R. N. Zare, *Optimizing chemical reactions with deep reinforcement learning*, ACS Cent. Sci **3**(12), 1337 (2017), doi:10.1021/acscentsci.7b00492.
- [70] A. Chervonenkis, *Early History of Support Vector Machines*, pp. 13–20, Springer Berlin, Heidelberg, ISBN 978-3-642-41135-9, doi:10.1007/978-3-642-41136-6_3 (2013).
- [71] B. E. Boser, I. M. Guyon and V. N. Vapnik, *A Training Algorithm for Optimal Margin Classifiers*, In *Proc. Fifth Ann. Workshop Compu. Learn. Theo.*, COLT '92, p. 144–152. Association for Computing Machinery, ISBN 089791497X, doi: 10.1145/130385.130401 (1992).
- [72] J. Platt, *Sequential minimal optimization: A fast algorithm for training support vector machines*, Tech. Rep. [MSR-TR-98-14](#), Microsoft (1998).
- [73] M. Minsky and S. Papert, *Perceptrons: An Introduction to Computational Geometry*, MIT Press, ISBN 0-262-13043-2, doi:10.7551/mitpress/11301.001.0001 (1969).
- [74] F. Rosenblatt, *The perceptron: A probabilistic model for information storage and organization in the brain*, Psychol. Rev. **65**(6), 386 (1958), doi:10.1037/h0042519.
- [75] A. N. Kolmogorov, *On the representation of continuous functions of many variables by superposition of continuous functions of one variable and addition*, In *Doklady Akademii Nauk*, vol. 114, pp. 953–956. Russian Academy of Sciences (1957).

- [76] G. Cybenko, *Approximation by superpositions of a sigmoidal function*, Math. Control Signals Syst. **2**(4), 303 (1989), doi:10.1007/BF02551274.
- [77] K. Hornik, *Approximation capabilities of multilayer feedforward networks*, Neural Netw. **4**(2), 251 (1991), doi:10.1016/0893-6080(91)90009-T.
- [78] D. E. Rumelhart, G. E. Hinton and R. J. Williams, *Learning representations by back-propagating errors*, Nature **323**(6088), 533 (1986), doi:10.1038/323533a0.
- [79] D. P. Kingma and M. Welling, *Auto-encoding variational Bayes*, In *ICLR 2014 - Int. Conf. Learn. Represent.* (2014), [arXiv:1312.6114](#).
- [80] D. J. Rezende, S. Mohamed and D. Wierstra, *Stochastic backpropagation and approximate inference in deep generative models*, In *ICML 2014 - Int. Conf. Mach. Learn.*, vol. 32, pp. 1278–1286 (2014), [arXiv:1401.4082](#).
- [81] A. Ng *et al.*, *Sparse autoencoder*, [CS294A Lecture notes](#), Stanford University (2011).
- [82] A. Makhzani and B. Frey, *K-sparse autoencoders*, In *ICLR 2014 - Int. Conf. Learn. Represent.* (2014), [arXiv:1312.5663](#).
- [83] P. Vincent, H. Larochelle, Y. Bengio and P.-A. Manzagol, *Extracting and composing robust features with denoising autoencoders*, In *ICML 2008 - 25th Int. Conf. Mach. Learn.*, pp. 1096–1103, doi:10.1145/1390156.1390294 (2008).
- [84] Y. Burda, R. Grosse and R. Salakhutdinov, *Importance weighted autoencoders*, In *ICLR 2016 - Int. Conf. Learn. Represent.* (2016), [arXiv:1509.00519](#).
- [85] B. Uria, M.-A. Côté, K. Gregor, I. Murray and H. Larochelle, *Neural autoregressive distribution estimation*, J. Mach. Learn. Res. **17**(1), 7184–7220 (2016), doi:10.5555/2946645.3053487.
- [86] S. Hochreiter and J. Schmidhuber, *Long short-term memory*, Neural Comput. **9**(8), 1735 (1997), doi:10.1162/neco.1997.9.8.1735.
- [87] K. Cho, B. van Merriënboer, D. Bahdanau and Y. Bengio, *On the properties of neural machine translation: Encoder–decoder approaches*, In *SSST-8 - 8th Workshop on Syntax, Semantics and Structure in Statistical Translation*, pp. 103–111, doi:10.3115/v1/W14-4012 (2014).
- [88] D. Wu, L. Wang and P. Zhang, *Solving statistical mechanics using variational autoregressive networks*, Phys. Rev. Lett. **122**(8), 080602 (2019), doi:10.1103/PhysRevLett.122.080602.

- [89] K. A. Nicoli, S. Nakajima, N. Strodthoff, W. Samek, K.-R. Müller and P. Kessel, *Asymptotically unbiased estimation of physical observables with neural samplers*, Phys. Rev. E **101**(2), 023304 (2020), doi:10.1103/PhysRevE.101.023304.
- [90] J.-G. Liu, L. Mao, P. Zhang and L. Wang, *Solving quantum statistical mechanics with variational autoregressive networks and quantum circuits*, Mach. Learn.: Sci. Technol. **2**(2), 025011 (2021), doi:10.1088/2632-2153/aba19d.
- [91] J. Carrasquilla, G. Torlai, R. G. Melko and L. Aolita, *Reconstructing quantum states with generative models*, Nat. Mach. Intell. **1**(3), 155–161 (2019), doi:10.1038/s42256-019-0028-1.
- [92] O. Sharir, Y. Levine, N. Wies, G. Carleo and A. Shashua, *Deep autoregressive models for the efficient variational simulation of many-body quantum systems*, Phys. Rev. Lett. **124**(2), 020503 (2020), doi:10.1103/PhysRevLett.124.020503.
- [93] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, Berlin, Heidelberg, ISBN 0387310738 (2006).
- [94] P. Mehta, M. Bukov, C.-H. Wang, A. G. Day, C. Richardson, C. K. Fisher and D. J. Schwab, *A high-bias, low-variance introduction to machine learning for physicists*, Phys. Rep. **810**, 1 (2019), doi:10.1016/j.physrep.2019.03.001.
- [95] A. Zhang, Z. C. Lipton, M. Li and A. J. Smola, *Dive into deep learning* (2021), [arXiv:2106.11342](https://arxiv.org/abs/2106.11342).
- [96] T. Neupert, M. H. Fischer, E. Greplova, K. Choo and M. Denner, *Introduction to machine learning for the sciences* (2021), [arXiv:2102.04883](https://arxiv.org/abs/2102.04883).
- [97] J. Carrasquilla and G. Torlai, *How to use neural networks to investigate quantum many-body physics*, PRX Quantum **2**, 040201 (2021), doi:10.1103/PRXQuantum.2.040201.
- [98] S. Sachdev, *Quantum Phase Transitions*, Cambridge University Press, doi:10.1017/cbo9780511973765 (2011).
- [99] N. Goldenfeld, *Lectures On Phase Transitions And The Renormalization Group*, CRC Press, doi:10.1201/9780429493492 (2018).
- [100] L. Onsager, *Crystal statistics. I. A two-dimensional model with an order-disorder transition*, Phys. Rev. **65**, 117 (1944), doi:10.1103/PhysRev.65.117.
- [101] F. J. Wegner, *Duality in generalized Ising models and phase transitions without local order parameters*, J. Math. Phys. **12**(10), 2259 (1971), doi:10.1063/1.1665530.
- [102] L. D. Landau, *On the theory of phase transitions. I.*, Phys. Z. Sowjet. **11**, 26 (1937), Reprinted in [Collected Papers of L. D. Landau](#).

- [103] L. D. Landau, *On the theory of phase transitions. II.*, Phys. Z. Sowjet. **11**, 545 (1937), Reprinted in [Collected Papers of L. D. Landau](#).
- [104] X.-G. Wen, *Topological orders in rigid states*, Int. J. Mod. Phys. B **4**(02), 239 (1990), doi:10.1142/S0217979290000139.
- [105] B. Bernevig and T. Hughes, *Topological Insulators and Topological Superconductors*, Princeton University Press, ISBN 9780691151755, doi:10.1515/9781400846733 (2013).
- [106] N. Käming, A. Dawid, K. Kottmann, M. Lewenstein, K. Sengstock, A. Dauphin and C. Weitenberg, *Unsupervised machine learning of topological phase transitions from experimental data*, Mach. Learn.: Sci. Technol. **2**, 035037 (2021), doi:10.1088/2632-2153/abffe7.
- [107] N. Sun, J. Yi, P. Zhang, H. Shen and H. Zhai, *Deep learning topological invariants of band insulators*, Phys. Rev. B **98**, 085402 (2018), doi:10.1103/PhysRevB.98.085402.
- [108] P. Zhang, H. Shen and H. Zhai, *Machine learning topological invariants with neural networks*, Phys. Rev. Lett. **120**, 066401 (2018), doi:10.1103/PhysRevLett.120.066401.
- [109] M. D. Caio, M. Caccin, P. Baireuther, T. Hyart and M. Fruchart, *Machine learning assisted measurement of local topological invariants* (2019), [arXiv:1901.03346](#).
- [110] N. L. Holanda and M. A. R. Griffith, *Machine learning topological phases in real space*, Phys. Rev. B **102**, 054107 (2020), doi:10.1103/PhysRevB.102.054107.
- [111] P. Baireuther, M. Płodzień, T. Ojanen, J. Tworzydło and T. Hyart, *Identifying Chern numbers of superconductors from local measurements*, SciPost Phys. Core **6**, 087 (2023), doi:10.21468/SciPostPhysCore.6.4.087.
- [112] P. Huembeli, A. Dauphin and P. Wittek, *Identifying quantum phase transitions with adversarial neural networks*, Phys. Rev. B **97**, 134109 (2018), doi:10.1103/PhysRevB.97.134109.
- [113] C. Fefferman, S. Mitter and H. Narayanan, *Testing the manifold hypothesis*, J. Am. Math. Soc. **29**(4), 983 (2016), doi:10.1090/jams/852.
- [114] L. Wang, *Discovering phase transitions with unsupervised learning*, Phys. Rev. B **94**, 195105 (2016), doi:10.1103/PhysRevB.94.195105.
- [115] S. J. Wetzel, *Unsupervised learning of phase transitions: From principal component analysis to variational autoencoders*, Phys. Rev. E **96**, 022140 (2017), doi:10.1103/PhysRevE.96.022140.

- [116] W. Hu, R. R. Singh and R. T. Scalettar, *Discovering phases, phase transitions, and crossovers through unsupervised machine learning: A critical examination*, Phys. Rev. E **95**(6), 062122 (2017), doi:10.1103/PhysRevE.95.062122.
- [117] B. Schölkopf, A. Smola and K.-R. Müller, *Nonlinear Component Analysis as a Kernel Eigenvalue Problem*, Neural Comput. **10**(5), 1299 (1998), doi:10.1162/089976698300017467.
- [118] L. Van der Maaten and G. Hinton, *Visualizing data using t-SNE*, [J. Mach. Learn. Res.](#) **9**(11) (2008).
- [119] L. McInnes, J. Healy and J. Melville, *UMAP: Uniform manifold approximation and projection for dimension reduction* (2018), [arXiv:1802.03426](#).
- [120] G. E. Hinton and S. T. Roweis, *Stochastic neighbor embedding*, In *NIPS 2002 - Adv. Neural Inf. Process. Syst.* (2002).
- [121] E. Greplova, A. Valenti, G. Boschung, F. Schäfer, N. Lörch and S. D. Huber, *Unsupervised identification of topological phase transitions using predictive models*, New J. Phys. **22**(4), 045003 (2020), doi:10.1088/1367-2630/ab7771.
- [122] J. Arnold, F. Schäfer, M. Žonda and A. U. J. Lode, *Interpretable and unsupervised phase classification*, Phys. Rev. Res. **3**, 033052 (2021), doi:10.1103/PhysRevResearch.3.033052.
- [123] J. Carrasquilla and R. G. Melko, *Machine learning phases of matter*, Nat. Phys. **13**(5), 431 (2017), doi:10.1038/nphys4035.
- [124] K. Kottmann, F. Metz, J. Fraxanet and N. Baldelli, *Variational quantum anomaly detection: Unsupervised mapping of phase diagrams on a physical quantum computer*, Phys. Rev. Res. **3**, 043184 (2021), doi:10.1103/PhysRevResearch.3.043184.
- [125] T. Szoldra, P. Sierant, M. Lewenstein and J. Zakrzewski, *Unsupervised detection of decoupled subspaces: Many-body scars and beyond*, Phys. Rev. B **105**, 224205 (2022), doi:10.1103/PhysRevB.105.224205.
- [126] K. Kottmann, P. Huembeli, M. Lewenstein and A. Acín, *Unsupervised phase discovery with deep anomaly detection*, Phys. Rev. Lett. **125**, 170603 (2020), doi:10.1103/PhysRevLett.125.170603.
- [127] T. Szoldra, P. Sierant, K. Kottmann, M. Lewenstein and J. Zakrzewski, *Detecting ergodic bubbles at the crossover to many-body localization using neural networks*, Phys. Rev. B **104**, L140202 (2021), doi:10.1103/PhysRevB.104.L140202.
- [128] E. P. Van Nieuwenburg, Y.-H. Liu and S. D. Huber, *Learning phase transitions by confusion*, Nat. Phys. **13**(5), 435 (2017), doi:10.1038/nphys4037.

- [129] Y.-H. Liu and E. P. L. van Nieuwenburg, *Discriminative cooperative networks for detecting phase transitions*, Phys. Rev. Lett. **120**, 176401 (2018), doi:10.1103/PhysRevLett.120.176401.
- [130] S. S. Lee and B. J. Kim, *Confusion scheme in machine learning detects double phase transitions and quasi-long-range order*, Phys. Rev. E **99**, 043308 (2019), doi:10.1103/PhysRevE.99.043308.
- [131] M. Richter-Laskowska, M. Kurpas and M. M. Maška, *Learning by confusion approach to identification of discontinuous phase transitions*, Phys. Rev. E **108**, 024113 (2023), doi:10.1103/PhysRevE.108.024113.
- [132] F. Schäfer and N. Lörch, *Vector field divergence of predictive model output as indication of phase transitions*, Phys. Rev. E **99**, 062107 (2019), doi:10.1103/PhysRevE.99.062107.
- [133] P. Ronhovde, S. Chakrabarty, D. Hu, M. Sahu, K. Sahu, K. Kelton, N. Mauro and Z. Nussinov, *Detecting hidden spatial and spatio-temporal structures in glasses and complex physical systems by multiresolution network clustering*, Eur. Phys. J. E **34**(9), 1 (2011), doi:10.1140/epje/i2011-11105-9.
- [134] P. Ronhovde, S. Chakrabarty, D. Hu, M. Sahu, K. K. Sahu, K. F. Kelton, N. A. Mauro and Z. Nussinov, *Detection of hidden structures for arbitrary scales in complex physical systems*, Sci. Rep. **2**(1), 1 (2012), doi:10.1038/srep00329.
- [135] R. A. Vargas-Hernández, J. Sous, M. Berciu and R. V. Krems, *Extrapolating quantum observables with machine learning: Inferring multiple phase transitions from properties of a single phase*, Phys. Rev. Lett. **121**, 255702 (2018), doi:10.1103/PhysRevLett.121.255702.
- [136] A. A. Shirinyan, V. K. Kozin, J. Hellsvik, M. Pereiro, O. Eriksson and D. Yudin, *Self-organizing maps as a method for detecting phase transitions and phase identification*, Phys. Rev. B **99**, 041108 (2019), doi:10.1103/PhysRevB.99.041108.
- [137] T. Mazaheri, B. Sun, J. Scher-Zagier, A. S. Thind, D. Magee, P. Ronhovde, T. Lookman, R. Mishra and Z. Nussinov, *Stochastic replica voting machine prediction of stable cubic and double perovskite materials and binary alloys*, Phys. Rev. Mater. **3**, 063802 (2019), doi:10.1103/PhysRevMaterials.3.063802.
- [138] O. Balabanov and M. Granath, *Unsupervised learning using topological data augmentation*, Phys. Rev. Res. **2**, 013354 (2020), doi:10.1103/PhysRevResearch.2.013354.
- [139] S.-J. Gu, *Fidelity approach to quantum phase transitions*, Int. J. Mod. Phys. B **24**(23), 4371 (2010), doi:10.1142/S0217979210056335.

- [140] B. S. Rem, N. Käming, M. Tarnowski, L. Asteria, N. Fläschner, C. Becker, K. Sengstock and C. Weitenberg, *Identifying quantum phase transitions using artificial neural networks on experimental data*, Nat. Phys. **15**, 917 (2019), doi:10.1038/s41567-019-0554-0.
- [141] A. Bohrdt, S. Kim, A. Lukin, M. Rispoli, R. Schittko, M. Knap, M. Greiner and J. Léonard, *Analyzing nonequilibrium quantum states through snapshots with artificial neural networks*, Phys. Rev. Lett. **127**, 150504 (2021), doi:10.1103/PhysRevLett.127.150504.
- [142] Z. C. Lipton, *The mythos of model interpretability*, Commun. ACM **61**(10), 35 (2018), doi:10.1145/3233231.
- [143] A. Bohrdt, C. S. Chiu, G. Ji, M. Xu, D. Greif, M. Greiner, E. Demler, F. Grusdt and M. Knap, *Classifying snapshots of the doped Hubbard model with machine learning*, Nat. Phys. **15**(9), 921 (2019), doi:10.1038/s41567-019-0565-x.
- [144] Y. Zhang, P. Ginsparg and E.-A. Kim, *Interpreting machine learning of topological quantum phase transitions*, Phys. Rev. Res. **2**, 023283 (2020), doi:10.1103/PhysRevResearch.2.023283.
- [145] M. Cranmer, A. Sanchez-Gonzalez, P. Battaglia, R. Xu, K. Cranmer, D. Spergel and S. Ho, *Discovering symbolic models from deep learning with inductive biases*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2006.11287](https://arxiv.org/abs/2006.11287).
- [146] P. Ponte and R. G. Melko, *Kernel methods for interpretable machine learning of order parameters*, Phys. Rev. B **96**, 205146 (2017), doi:10.1103/PhysRevB.96.205146.
- [147] J. Greitemann, K. Liu and L. Pollet, *Probing hidden spin order with interpretable machine learning*, Phys. Rev. B **99**, 060404 (2019), doi:10.1103/PhysRevB.99.060404.
- [148] K. Liu, J. Greitemann and L. Pollet, *Learning multiple order parameters with interpretable machines*, Phys. Rev. B **99**, 104410 (2019), doi:10.1103/PhysRevB.99.104410.
- [149] R. Iten, T. Metger, H. Wilming, L. Del Rio and R. Renner, *Discovering physical concepts with neural networks*, Phys. Rev. Lett. **124**(1), 010508 (2020), doi:10.1103/PhysRevLett.124.010508.
- [150] S. J. Wetzel and M. Scherzer, *Machine learning of explicit order parameters: From the Ising model to $SU(2)$ lattice gauge theory*, Phys. Rev. B **96**(18), 184410 (2017), doi:10.1103/PhysRevB.96.184410.

- [151] S. J. Wetzel, R. G. Melko, J. Scott, M. Panju and V. Ganesh, *Discovering symmetry invariants and conserved quantities by interpreting Siamese neural networks*, Phys. Rev. Res. **2**, 033499 (2020), doi:10.1103/PhysRevResearch.2.033499.
- [152] C. Miles, A. Bohrdt, R. Wu, C. Chiu, M. Xu, G. Ji, M. Greiner, K. Q. Weinberger, E. Demler and E.-A. Kim, *Correlator convolutional neural networks: An interpretable architecture for image-like quantum matter data*, Nat. Commun. **12**(1), 1 (2021), doi:10.1038/s41467-021-23952-w.
- [153] S. K. Radha and C. Jao, *Generalized quantum similarity learning* (2022), [arXiv:2201.02310](#).
- [154] Z. Patel, E. Merali and S. J. Wetzel, *Unsupervised learning of Rydberg atom array phase diagram with Siamese neural networks*, New J. Phys. **24**(11), 113021 (2022), doi:10.1088/1367-2630/ac9c7a.
- [155] X.-Q. Han, S.-S. Xu, Z. Feng, R.-Q. He and Z.-Y. Lu, *Framework for contrastive learning phases of matter based on visual representations*, Chinese Phys. Lett. **40**(2), 027501 (2023), doi:10.1088/0256-307x/40/2/027501.
- [156] Z. Liu and M. Tegmark, *Machine learning conservation laws from trajectories*, Phys. Rev. Lett. **126**, 180604 (2021), doi:10.1103/PhysRevLett.126.180604.
- [157] Z. Liu, V. Madhavan and M. Tegmark, *Machine learning conservation laws from differential equations*, Phys. Rev. E **106**, 045307 (2022), doi:10.1103/PhysRevE.106.045307.
- [158] S. Ha and H. Jeong, *Discovering invariants via machine learning*, Phys. Rev. Res. **3**, L042035 (2021), doi:10.1103/PhysRevResearch.3.L042035.
- [159] N. S. Keskar, J. Nocedal, P. T. P. Tang, D. Mudigere and M. Smelyanskiy, *On large-batch training for deep learning: Generalization gap and sharp minima*, In *ICLR 2017 - Int. Conf. Learn. Represent.* (2017), [arXiv:1609.04836](#).
- [160] L. Wu, Z. Zu and W. E, *Towards understanding generalization of deep learning: Perspective of loss landscapes* (2017), [arXiv:1706.10239](#).
- [161] P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov and A. G. Wilson, *Averaging weights leads to wider optima and better generalization*, In *UAI 2018 - 34th Conf. Uncertain. Artif. Intell.*, vol. 2, pp. 876–885 (2018), [arXiv:1803.05407](#).
- [162] H. He, G. Huang and Y. Yuan, *Asymmetric valleys: Beyond sharp and flat local minima*, In *NeurIPS 2019 - Adv. Neural Inf. Process. Syst.* (2019), [arXiv:1902.00744](#).

- [163] L. Dinh, R. Pascanu, S. Bengio and Y. Bengio, *Sharp minima can generalize for deep nets*, In *ICML 2017 - 34th Int. Conf. Mach. Learn.*, vol. 3, pp. 1705–1714 (2017), [arXiv:1703.04933](#).
- [164] A. Dawid, P. Huembeli, M. Tomza, M. Lewenstein and A. Dauphin, *Hessian-based toolbox for reliable and interpretable machine learning in physics*, *Mach. Learn.: Sci. Technol.* **3**, 015002 (2022), doi:10.1088/2632-2153/ac338d.
- [165] P. W. Koh and P. Liang, *Understanding black-box predictions via influence functions*, In *ICML 2017 - 34th Int. Conf. Mach. Learn.*, vol. 70, pp. 1885–1894. PMLR (2017), [arXiv:1703.04730](#).
- [166] P. Schulam and S. Saria, *Can you trust this prediction? Auditing pointwise reliability after learning*, In *AISTATS 2019 - Int. Conf. Artif. Intell. Stat.*, vol. 89, pp. 1022–1031. PLMR (2020), [arXiv:1901.00403](#).
- [167] D. Madras, J. Atwood and A. D’Amour, *Detecting extrapolation with local ensembles*, In *ICLR 2020 - Int. Conf. Learn. Represent.* (2020), [arXiv:1910.09573](#).
- [168] A. Dawid, P. Huembeli, M. Tomza, M. Lewenstein and A. Dauphin, *Phase detection with neural networks: interpreting the black box*, *New J. Phys.* **22**(11), 115001 (2020), doi:10.1088/1367-2630/abc463.
- [169] J. Arnold and F. Schäfer, *Replacing neural networks by optimal analytical predictors for the detection of phase transitions*, *Phys. Rev. X* **12**, 031044 (2022), doi:10.1103/PhysRevX.12.031044.
- [170] J. Arnold, F. Schäfer, A. Edelman and C. Bruder, *Mapping out phase diagrams with generative classifiers*, *Phys. Rev. Lett.* **132**, 207301 (2024), doi:10.1103/PhysRevLett.132.207301.
- [171] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, [GitHub.io](#), ISBN 9780244768522 (2019).
- [172] K.-R. Müller, S. Mika, K. Tsuda and K. Schölkopf, *An introduction to kernel-based learning algorithms*, In *Handbook of Neural Network Signal Processing*, pp. 94–133. CRC Press, doi:10.1201/9781315220413 (2018).
- [173] B. Schölkopf and A. J. Smola, *Learning with Kernels*, The MIT Press, ISBN 9780262256933, doi:10.7551/mitpress/4175.001.0001 (2018).
- [174] T. Hofmann, B. Schölkopf and A. J. Smola, *Kernel methods in machine learning*, *Ann. Statist.* **36**(3), 1171 (2008), doi:10.1214/0090536070000000677.
- [175] G. Bachman and L. Narici, *Functional analysis*, Dover Publications, Mineola, New York, ISBN 9780486136554 (2000).

- [176] J. Mercer, *XVI. Functions of positive and negative type, and their connection the theory of integral equations*, Philos. Trans. Royal Soc. A **209**(441-458), 415 (1909), doi:10.1098/rsta.1909.0016.
- [177] N. Aronszajn, *Theory of reproducing kernels*, Trans. Am. Math. Soc. **68**(3), 337 (1950), doi:10.2307/1990404.
- [178] B. Schölkopf, R. Herbrich and A. J. Smola, *A Generalized Representer Theorem*, In *Computational Learning Theory*, pp. 416–426. Springer, doi:10.1007/3-540-44581-1_27 (2001).
- [179] B. Schölkopf, A. Smola and K.-R. Müller, *Kernel principal component analysis*, In *ICANN 1997 - Int. Conf. Neural Netw.*, pp. 583–588. Springer, doi:10.1007/BFb0020217 (1997).
- [180] C. Saunders, A. Gammerman and V. Vovk, *Ridge Regression Learning Algorithm in Dual Variables*, In *Proceedings of the Fifteenth International Conference on Machine Learning*, ICML '98, p. 515–521. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, ISBN 1558605568, doi:10.5555/645527.657464 (1998).
- [181] A. J. Smola and B. Schölkopf, *On a kernel-based method for pattern recognition, regression, approximation, and operator inversion*, Algorithmica **22**(1), 211 (1998), doi:10.1007/PL00013831.
- [182] R. Garnett, *Bayesian Optimization*, Cambridge University Press, [in preparation](#) (2022).
- [183] R. M. Neal, *Bayesian Learning for Neural Networks*, vol. 118 of *Lecture Notes in Statistics*, Springer, doi:10.1007/978-1-4612-0745-0 (2012).
- [184] N. Cressie, *The origins of kriging*, Math. Geol. **22**(3), 239 (1990), doi:10.1007/BF00889887.
- [185] P. I. Frazier, *A tutorial on Bayesian optimization* (2018), [arXiv:1807.02811](#).
- [186] G. Schwarz, *Estimating the dimension of a model*, Ann. Stat. pp. 461–464 (1978), doi:10.1214/aos/1176344136.
- [187] P. Stoica and Y. Selen, *Model-order selection: a review of information criterion rules*, IEEE Signal Process. Mag. **21**(4), 36 (2004), doi:10.1109/MSP.2004.1311138.
- [188] H. Akaike, *A new look at the statistical model identification*, IEEE Trans. Automat. Contr. **19**(6), 716 (1974), doi:10.1109/TAC.1974.1100705.

- [189] D. Duvenaud, J. Lloyd, R. Grosse, J. Tenenbaum and G. Zoubin, *Structure discovery in nonparametric regression through compositional kernel search*, In *ICML 2013 - Int. Conf. Mach. Learn.*, vol. 28, pp. 1166–1174. PMLR (2013), [arXiv:1302.4922](#).
- [190] D. Duvenaud, H. Nickisch and C. E. Rasmussen, *Additive Gaussian processes*, In *NIPS 2011 - Adv. Neural Inf. Process. Syst.* (2011), [arXiv:1112.4394](#).
- [191] J. Dai and R. V. Krems, *Interpolation and extrapolation of global potential energy surfaces for polyatomic systems by Gaussian processes with composite kernels*, *J. Chem. Theory Comput.* **16**(3), 1386 (2020), doi:10.1021/acs.jctc.9b00700.
- [192] R. A. Vargas-Hernández and J. R. Gardner, *Gaussian processes with spectral delta kernel for higher accurate potential energy surfaces for large molecules* (2021), [arXiv:2109.14074](#).
- [193] N. Q. Su, J. Chen, Z. Sun, D. H. Zhang and X. Xu, *$H + H_2$ quantum dynamics using potential energy surfaces based on the XYG3 type of doubly hybrid density functionals: Validation of the density functionals*, *J. Chem. Phys.* **142**, 084107 (2015), doi:10.1063/1.4913196.
- [194] R. A. Vargas-Hernández, Y. Guan, D. H. Zhang and R. V. Krems, *Bayesian optimization for the inverse scattering problem in quantum reaction dynamics*, *New J. Phys.* **21**, 22001 (2019), doi:10.1088/1367-2630/ab0099.
- [195] Z. Deng, I. Tutunnikov, I. S. Averbukh, M. Thachuk and R. V. Krems, *Bayesian optimization for inverse problems in time-dependent quantum dynamics*, *J. Chem. Phys.* **153**(16), 164111 (2020), doi:10.1063/5.0015896.
- [196] J. T. Cantin, G. Alexandrowicz and R. V. Krems, *Transfer-matrix theory of surface spin-echo experiments with molecules*, *Phys. Rev. A* **101**(6), 062703 (2020), doi:10.1103/PhysRevA.101.062703.
- [197] N. Sugisawa, H. Sugisawa, Y. Otake, R. V. Krems, H. Nakamura and S. Fuse, *Rapid and mild one-flow synthetic approach to unsymmetrical sulfamides guided by Bayesian optimization*, *Chem. Methods* **1**(11), 484 (2021), doi:10.1002/cmtd.202100053.
- [198] A. Jasinski, J. Montaner, R. C. Forrey, B. H. Yang, P. C. Stancil, N. Balakrishnan, J. Dai, R. A. Vargas-Hernández and R. V. Krems, *Machine learning corrected quantum dynamics calculations*, *Phys. Rev. Res.* **2**(3), 32051 (2020), doi:10.1103/PhysRevResearch.2.032051.
- [199] R. A. Vargas Hernandez, *Bayesian optimization for calibrating and selecting hybrid-density functional models*, *J. Phys. Chem. A* **124**(20), 4053 (2020), doi:10.1021/acs.jpca.0c01375.

- [200] J. Proppe, S. Gugler and M. Reiher, *Gaussian process-based refinement of dispersion corrections*, J. Chem. Theory Comput. **15**(11), 6046 (2019), doi:10.1021/acs.jctc.9b00627.
- [201] R. Tamura and K. Hukushima, *Bayesian optimization for computationally extensive probability distributions*, PLoS One **13**(3), 1 (2018), doi:10.1371/journal.pone.0193785.
- [202] S. Carr, R. Garnett and C. Lo, *BASC: Applying Bayesian optimization to the search for global minima on potential energy surfaces*, In *ICML 2016 - Int. Conf. Mach. Learn.*, vol. 48, pp. 898–907. PMLR (2016).
- [203] L. Chan, G. R. Hutchison and G. M. Morris, *Bayesian optimization for conformer generation*, J. Cheminformatics **11**(1), 32 (2019), doi:10.1186/s13321-019-0354-7.
- [204] R. A. Vargas-Hernández, C. Chuang and P. Brumer, *Multi-objective optimization for retinal photoisomerization models with respect to experimental observables*, J. Chem. Phys. **155**(23), 234109 (2021), doi:10.1063/5.0060259.
- [205] J. Duris, D. Kennedy, A. Hanuka, J. Shtalenkova, A. Edelen, P. Baxevasis, A. Egger, T. Cope, M. McIntire, S. Ermon and D. Ratner, *Bayesian optimization of a free-electron laser*, Phys. Rev. Lett. **124**, 124801 (2020), doi:10.1103/PhysRevLett.124.124801.
- [206] S. Jalas, M. Kirchen, P. Messner, P. Winkler, L. Hübner, J. Dirkwinkel, M. Schnepf, R. Lehe and A. R. Maier, *Bayesian optimization of a laser-plasma accelerator*, Phys. Rev. Lett. **126**, 104801 (2021), doi:10.1103/PhysRevLett.126.104801.
- [207] R. J. Shalloo, S. J. D. Dann, J.-N. Gruse, C. I. D. Underwood, A. F. Antoine, C. Arran, M. Backhouse, C. D. Baird, M. D. Balcazar, N. Bourgeois, J. A. Cardarelli, P. Hatfield *et al.*, *Automation and control of laser wakefield accelerators using Bayesian optimization*, Nat. Commun. **11**(1), 6355 (2020), doi:10.1038/s41467-020-20245-6.
- [208] T. Ueno, T. D. Rhone, Z. Hou, T. Mizoguchi and K. Tsuda, *COMBO: An efficient Bayesian optimization library for materials science*, Mater. Discov. **4**, 18 (2016), doi:10.1016/j.md.2016.04.001.
- [209] R. Jalem, K. Kanamori, I. Takeuchi, M. Nakayama, H. Yamasaki and T. Saito, *Bayesian-driven first-principles calculations for accelerating exploration of fast ion conductors for rechargeable battery application*, Sci. Rep. **8**(1), 5845 (2018), doi:10.1038/s41598-018-23852-y.

- [210] S. Ju, T. Shiga, L. Feng, Z. Hou, K. Tsuda and J. Shiomi, *Designing nanostructures for phonon transport via Bayesian optimization*, Phys. Rev. X **7**, 021024 (2017), doi:10.1103/PhysRevX.7.021024.
- [211] J. Kuhn, J. Spitz, P. Sonnweber-Ribic, M. Schneider and T. Böhlke, *Identifying material parameters in crystal plasticity by Bayesian optimization*, Optim. Eng. (2021), doi:10.1007/s11081-021-09663-7.
- [212] R.-R. Griffiths and J. M. Hernández-Lobato, *Constrained Bayesian optimization for automatic chemical design using variational autoencoders*, Chem. Sci. **11**, 577 (2020), doi:10.1039/C9SC04026A.
- [213] A. Deshwal, C. M. Simon and J. R. Doppa, *Bayesian optimization of nanoporous materials*, Mol. Syst. Des. Eng. **6**, 1066 (2021), doi:10.1039/D1ME00093D.
- [214] F. Häse, L. M. Roch, C. Kreisbeck and A. Aspuru-Guzik, *Phoenix: A Bayesian optimizer for chemistry*, ACS Cent. Sci. **4**(9), 1134 (2018), doi:10.1021/acscentsci.8b00307.
- [215] F. Häse, M. Aldeghi, R. J. Hickman, L. M. Roch and A. Aspuru-Guzik, *Gryffin: An algorithm for Bayesian optimization of categorical variables informed by expert knowledge*, Appl. Phys. Rev. **8**(3), 031406 (2021), doi:10.1063/5.0048164.
- [216] A. Biswas, A. N. Morozovska, M. Ziatdinov, E. A. Eliseev and S. V. Kalinin, *Multi-objective Bayesian optimization of ferroelectric materials with interfacial control for memory and energy storage applications*, J. Appl. Phys. **130**(20), 204102 (2021), doi:10.1063/5.0068903.
- [217] Y. Wang, T.-Y. Chen and D. G. Vlachos, *NEXTorch: A design and Bayesian optimization toolkit for chemical sciences and engineering*, J. Chem. Inf. Model. **61**(11), 5312 (2021), doi:10.1021/acs.jcim.1c00637.
- [218] M. Aldeghi, F. Häse, R. J. Hickman, I. Tamblyn and A. Aspuru-Guzik, *Golem: An algorithm for robust experiment and process optimization*, Chem. Sci. **12**, 14792 (2021), doi:10.1039/D1SC01545A.
- [219] Z. Vendeiro, J. Ramette, A. Rudelis, M. Chong, J. Sinclair, L. Stewart, A. Urvoy and V. Vuletić, *Machine-learning-accelerated Bose-Einstein condensation*, Phys. Rev. Res. **4**, 043216 (2022), doi:10.1103/PhysRevResearch.4.043216.
- [220] H. Sugisawa, T. Ida and R. V. Krems, *Gaussian process model of 51-dimensional potential energy surface for protonated imidazole dimer*, J. Chem. Phys. **153**(11), 114101 (2020), doi:10.1063/5.0023492.

- [221] C. Puzzarini, J. Bloino, N. Tasinato and V. Barone, *Accuracy and interpretability: The devil and the holy grail. New routes across old boundaries in computational spectroscopy*, Chem. Rev. **119**(13), 8131 (2019), doi:10.1021/acs.chemrev.9b00007.
- [222] F. Herrera, K. W. Madison, R. V. Krems and M. Berciu, *Investigating polaron transitions with polar molecules*, Phys. Rev. Lett. **110**(22), 223002 (2013), doi:10.1103/PhysRevLett.110.223002.
- [223] P. Deglmann, A. Schäfer and C. Lennartz, *Application of quantum calculations in the chemical industry—an overview*, International Journal of Quantum Chemistry **115**(3), 107 (2015).
- [224] Y. Cao, J. Romero, J. P. Olson *et al.*, *Quantum chemistry in the age of quantum computing*, Chemical reviews **119**(19), 10856 (2019).
- [225] A. J. McCaskey, Z. P. Parks, J. Jakowski *et al.*, *Quantum chemistry as a benchmark for near-term quantum computers*, npj Quantum Information **5**(1), 99 (2019).
- [226] A. N. Ciavarella and I. A. Chernyshev, *Preparation of the $SU(3)$ lattice Yang-Mills vacuum with variational quantum methods*, Phys. Rev. D **105**(7), 074504 (2022).
- [227] M. C. Banuls, R. Blatt, J. Catani *et al.*, *Simulating lattice gauge theories within quantum technologies*, The European physical journal D **74**, 1 (2020).
- [228] G. Iannelli and K. Jansen, *Noisy Bayesian optimization for variational quantum eigensolvers*, ArXiv e-prints (2021), [arXiv:2112.00426](https://arxiv.org/abs/2112.00426).
- [229] J. Mueller, W. Lavrijsen, C. Iancu and W. A. de Jong, *Accelerating noisy VQE optimization with Gaussian processes*, 2022 IEEE International Conference on Quantum Computing and Engineering (QCE) pp. 215–225 (2022).
- [230] K. A. Nicoli, C. J. Anders, L. Funcke, T. Hartung, K. Jansen, S. Kuhn, K. Müller, P. Sornati, P. Kessel and S. Nakajima, *Physics-informed Bayesian optimization of variational quantum circuits*, In *NeurIPS 2023 - Adv. Neural Inf. Process. Syst.* (2023).
- [231] Nakanishi, Ken M. and Fujii, Keisuke and Todo, Synge, *Sequential minimal optimization for quantum-classical hybrid algorithms*, Phys. Rev. Res. **2**, 043158 (2020), doi:10.1103/PhysRevResearch.2.043158.
- [232] J. Platt, *Sequential minimal optimization : A fast algorithm for training support vector machines*, Microsoft Research Technical Report (1998).

- [233] K. Asnaashari and R. V. Krems, *Gradient domain machine learning with composite kernels: improving the accuracy of PES and force fields for large molecules*, Mach. Learn.: Sci. Technol. **3**(1), 015005 (2021), doi:10.1088/2632-2153/ac3845.
- [234] A. G. Wilson, Z. Hu, R. Salakhutdinov and E. P. Xing, *Deep kernel learning*, In *AISTATS 2016 - Int. Conf. Artif. Intell. Stat.* (2016), [arXiv:1511.02222](#).
- [235] S. Sun, G. Zhang, C. Wang, W. Zeng, J. Li and R. Grosse, *Differentiable compositional kernel learning for Gaussian processes*, In *ICML 2018 - Int. Conf. Mach. Learn.* (2018), [arXiv:1806.04326](#).
- [236] J. Gardner, G. Pleiss, K. Q. Weinberger, D. Bindel and A. G. Wilson, *GPyTorch: Blackbox matrix-matrix Gaussian process inference with GPU acceleration*, In *NeurIPS 2018 - Adv. Neural Inf. Process. Syst.* (2018), [arXiv:1809.11165](#).
- [237] B. Charlier, J. Feydy, J. A. Glaunès, F.-D. Collin and G. Durif, *Kernel operations on the GPU, with Autodiff, without memory overflows*, J. Mach. Learn. Res. **22**(74), 1 (2021), [arXiv:2004.11127](#).
- [238] A. G. d. G. Matthews, M. van der Wilk, T. Nickson, K. Fujii, A. Boukouvalas, P. León-Villagrà, Z. Ghahramani and J. Hensman, *GPflow: A Gaussian process library using TensorFlow*, J. Mach. Learn. Res. **18**(40), 1 (2017), [arXiv:1610.08733](#).
- [239] M. Blondel, Q. Berthet, M. Cuturi, R. Frostig, S. Hoyer, F. Llinares-López, F. Pedregosa and J.-P. Vert, *Efficient and modular implicit differentiation* (2021), [arXiv:2105.15183](#).
- [240] H.-Y. Huang, R. Kueng and J. Preskill, *Predicting many properties of a quantum system from very few measurements*, Nat. Phys. **16**(10), 1050–1057 (2020), doi:10.1038/s41567-020-0932-7.
- [241] C. E. Rasmussen and C. K. I. Williams, *Gaussian Processes for Machine Learning*, Adaptive Computation and Machine Learning. MIT Press, ISBN 9780262256834, doi:10.7551/mitpress/3206.001.0001 (2005).
- [242] R. V. Krems, *Bayesian machine learning for quantum molecular dynamics*, Phys. Chem. Chem. Phys. **21**(25), 13392 (2019), doi:10.1039/c9cp01883b.
- [243] R. A. Vargas-Hernández and R. V. Krems, *Physical Extrapolation of Quantum Observables by Generalization with Gaussian Processes*, pp. 171–194, Springer International Publishing, Cham, ISBN 978-3-030-40245-7, doi:10.1007/978-3-030-40245-7_9 (2020).
- [244] H.-Y. Huang, R. Kueng, G. Torlai, V. V. Albert and J. Preskill, *Provably efficient machine learning for quantum many-body problems*, Science **377**(6613) (2022), doi:10.1126/science.abk3333.

- [245] P. A. M. Dirac and R. H. Fowler, *Quantum mechanics of many-electron systems*, Proc. R. Soc. A: Math. Phys. Eng. Sci. **123**(792), 714 (1929), doi:10.1098/rspa.1929.0094.
- [246] G. Carleo and M. Troyer, *Solving the quantum many-body problem with artificial neural networks*, Science **355**(6325), 602–606 (2017), doi:10.1126/science.aag2302.
- [247] K. Choo, A. Mezzacapo and G. Carleo, *Fermionic neural-network states for ab-initio electronic structure*, Nat. Commun. **11**(1), 2368 (2020), doi:10.1038/s41467-020-15724-9.
- [248] H. Saito, *Solving the Bose–Hubbard model with machine learning*, J. Phys. Soc. Jpn. **86**(9), 093001 (2017), doi:10.7566/jpsj.86.093001.
- [249] S. R. White, *Density matrix formulation for quantum renormalization groups*, Phys. Rev. Lett. **69**, 2863 (1992), doi:10.1103/PhysRevLett.69.2863.
- [250] U. Schollwöck, *The density-matrix renormalization group in the age of matrix product states*, Ann. Phys. (N. Y.) **326**(1), 96–192 (2011), doi:10.1016/j.aop.2010.09.012.
- [251] R. Orús, *A practical introduction to tensor networks: Matrix product states and projected entangled pair states*, Ann. Phys. (N. Y.) **349**, 117–158 (2014), doi:10.1016/j.aop.2014.06.013.
- [252] M. V. den Nest, *Simulating quantum computers with probabilistic methods* (2010), [arXiv:0911.1624](https://arxiv.org/abs/0911.1624).
- [253] W. K. Hastings, *Monte Carlo sampling methods using Markov chains and their applications*, Biometrika **57**(1), 97 (1970), doi:10.2307/2334940.
- [254] R. Jastrow, *Many-body problem with strong forces*, Phys. Rev. **98**, 1479 (1955), doi:10.1103/PhysRev.98.1479.
- [255] E. Manousakis, *The spin- $\frac{1}{2}$ Heisenberg antiferromagnet on a square lattice and its application to the cuprous oxides*, Rev. Mod. Phys. **63**, 1 (1991), doi:10.1103/RevModPhys.63.1.
- [256] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss *et al.*, *Language models are few-shot learners*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2005.14165](https://arxiv.org/abs/2005.14165).
- [257] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski and A. Joulin, *Emerging Properties in Self-Supervised Vision Transformers*, In *Proc. IEEE Int. Conf. Comput. Vis.*, pp. 9650–9660, doi:10.1109/ICCV48922.2021.00951 (2021).

- [258] A. Nichol, P. Dhariwal, A. Ramesh, P. Shyam, P. Mishkin, B. McGrew, I. Sutskever and M. Chen, *GLIDE: Towards photorealistic image generation and editing with text-guided diffusion models* (2021), [arXiv:2112.10741](#).
- [259] A. Barra, A. Bernacchia, E. Santucci and P. Contucci, *On the equivalence of Hopfield networks and Boltzmann machines*, Neural Netw. **34**, 1 (2012), doi: 10.1016/j.neunet.2012.06.003.
- [260] G. Montufar, *Restricted Boltzmann machines: Introduction and review* (2018), [arXiv:1806.07066](#).
- [261] D.-L. Deng, X. Li and S. Das Sarma, *Quantum entanglement in neural network states*, Phys. Rev. X **7**(2) (2017), doi:10.1103/PhysRevX.7.021021.
- [262] J. Chen, S. Cheng, H. Xie, L. Wang and T. Xiang, *Equivalence of restricted Boltzmann machines and tensor network states*, Phys. Rev. B **97**(8) (2018), doi: 10.1103/PhysRevB.97.085104.
- [263] X. Gao and L.-M. Duan, *Efficient representation of quantum many-body states with deep neural networks*, Nat. Commun. **8**(1) (2017), doi:10.1038/s41467-017-00705-2.
- [264] D. Luo, G. Carleo, B. K. Clark and J. Stokes, *Gauge equivariant neural networks for quantum lattice gauge theories*, Phys. Rev. Lett. **127**, 276402 (2021), doi: 10.1103/PhysRevLett.127.276402.
- [265] A. Bansal, X. Chen, B. Russell, A. Gupta and D. Ramanan, *PixelNet: Representation of the pixels, by the pixels, and for the pixels* (2017), [arXiv:1702.06506](#).
- [266] M. Hibat-Allah, M. Ganahl, L. E. Hayward, R. G. Melko and J. Carrasquilla, *Recurrent neural network wave functions*, Phys. Rev. Res. **2**(2), 023358 (2020), doi:10.1103/PhysRevResearch.2.023358.
- [267] M. Schmitt and M. Heyl, *Quantum many-body dynamics in two dimensions with artificial neural networks*, Phys. Rev. Lett. **125**, 100503 (2020), doi:10.1103/PhysRevLett.125.100503.
- [268] C. Roth and A. H. MacDonald, *Group convolutional neural networks improve quantum state accuracy* (2021), [arXiv:2104.05085](#).
- [269] I. Glasser, N. Pancotti, M. August, I. D. Rodriguez and J. I. Cirac, *Neural-network quantum states, string-bond states, and chiral topological states*, Phys. Rev. X **8**, 011006 (2018), doi:10.1103/PhysRevX.8.011006.
- [270] O. Sharir, A. Shashua and G. Carleo, *Neural tensor contractions and the expressive power of deep neural quantum states*, Phys. Rev. B **106**, 205136 (2022), doi: 10.1103/PhysRevB.106.205136.

- [271] Y. Levine, O. Sharir, N. Cohen and A. Shashua, *Quantum entanglement in deep learning architectures*, Phys. Rev. Lett. **122**, 065301 (2019), doi:10.1103/PhysRevLett.122.065301.
- [272] P. Calabrese and J. Cardy, *Entanglement entropy and quantum field theory*, J. Stat. Mech. **2004**, P06002 (2004), doi:10.1088/1742-5468/2004/06/p06002.
- [273] J. Eisert, M. Cramer and M. B. Plenio, *Colloquium: Area laws for the entanglement entropy*, Rev. Mod. Phys. **82**, 277 (2010), doi:10.1103/RevModPhys.82.277.
- [274] M. Hibat-Allah, E. M. Inack, R. Wiersema, R. G. Melko and J. Carrasquilla, *Variational neural annealing*, Nat. Mach. Intell. **3**, 952 (2021), doi:10.1038/s42256-021-00401-3.
- [275] K. Choo, G. Carleo, N. Regnault and T. Neupert, *Symmetries and many-body excitations with neural-network quantum states*, Phys. Rev. Lett. **121**, 167204 (2018), doi:10.1103/PhysRevLett.121.167204.
- [276] A. Valenti, E. Greplova, N. H. Lindner and S. D. Huber, *Correlation-enhanced neural networks as interpretable variational quantum states*, Phys. Rev. Res. **4**, L012010 (2022), doi:10.1103/PhysRevResearch.4.L012010.
- [277] G. Carleo, Y. Nomura and M. Imada, *Constructing exact representations of quantum many-body systems with deep neural networks*, Nat. Commun. **9**, 5322 (2018), doi:10.1038/s41467-018-07520-3.
- [278] R. Kaubruegger, L. Pastori and J. C. Budich, *Chiral topological phases from artificial neural networks*, Phys. Rev. B **97**, 195136 (2018), doi:10.1103/PhysRevB.97.195136.
- [279] Y. Zheng, H. He, N. Regnault and B. A. Bernevig, *Restricted Boltzmann machines and matrix product states of one-dimensional translationally invariant stabilizer codes*, Phys. Rev. B **99**, 155129 (2019), doi:10.1103/PhysRevB.99.155129.
- [280] S. Lu, X. Gao and L.-M. Duan, *Efficient representation of topologically ordered states with restricted Boltzmann machines*, Phys. Rev. B **99**, 155136 (2019), doi:10.1103/PhysRevB.99.155136.
- [281] Y. Huang and J. E. Moore, *Neural network representation of tensor network and chiral states*, Phys. Rev. Lett. **127**, 170601 (2021), doi:10.1103/PhysRevLett.127.170601.
- [282] C.-Y. Park and M. J. Kastoryano, *Geometry of learning neural quantum states*, Phys. Rev. Res. **2**, 023232 (2020), doi:10.1103/PhysRevResearch.2.023232.

- [283] S.-H. Lin and F. Pollmann, *Scaling of neural-network quantum states for time evolution*, Phys. Status Solidi B **259**(5), 2100172 (2022), doi:10.1002/pssb.202100172.
- [284] F. Vicentini, D. Hofmann, A. Szabó, D. Wu, C. Roth, C. Giuliani, G. Pescia, J. Nys, V. Vargas-Calderon, N. Astrakhantsev and G. Carleo, *NetKet 3: Machine learning toolbox for many-body quantum systems* (2021), [arXiv:2112.10526](https://arxiv.org/abs/2112.10526).
- [285] X. Yuan, S. Endo, Q. Zhao, Y. Li and S. C. Benjamin, *Theory of variational quantum simulation*, Quantum **3**, 191 (2019), doi:10.22331/q-2019-10-07-191.
- [286] G. Carleo, F. Becca, M. Schiro and M. Fabrizio, *Localization and glassy dynamics of many-body quantum systems*, Sci. Rep. **2**, 243 (2012), doi:10.1038/srep00243.
- [287] I. L. Gutiérrez and C. B. Mendl, *Real time evolution with neural-network quantum states*, Quantum **6**, 627 (2022), doi:10.22331/q-2022-01-20-627.
- [288] D. Hofmann, G. Fabiani, J. Mentink, G. Carleo and M. Sentef, *Role of stochastic noise and generalization error in the time propagation of neural-network quantum states*, SciPost Phys. **12**(5) (2022), doi:10.21468/scipostphys.12.5.165.
- [289] S. Sorella, *Green function Monte Carlo with stochastic reconfiguration*, Phys. Rev. Lett. **80**, 4558 (1998), doi:10.1103/PhysRevLett.80.4558.
- [290] F. Becca and S. Sorella, *Quantum Monte Carlo Approaches for Correlated Systems*, Cambridge University Press, ISBN 9781316417041, doi:10.1017/9781316417041 (2017).
- [291] D. Hangleiter, I. Roth, D. Nagaj and J. Eisert, *Easing the Monte Carlo sign problem*, Sci. Adv. **6**, eabb8341 (2020), doi:10.1126/sciadv.abb8341.
- [292] D. Luo and B. K. Clark, *Backflow transformations via neural networks for quantum many-body wave functions*, Phys. Rev. Lett. **122**, 226401 (2019), doi:10.1103/PhysRevLett.122.226401.
- [293] J. Hermann, Z. Schätzle and F. Noé, *Deep-neural-network solution of the electronic Schrödinger equation*, Nat. Chem. **12**, 891–897 (2020), doi:10.1038/s41557-020-0544-y.
- [294] D. Pfau, J. S. Spencer, A. G. Matthews and W. M. C. Foulkes, *Ab initio solution of the many-electron Schrödinger equation with deep neural networks*, Phys. Rev. Res. **2**, 033429 (2020), doi:10.1103/PhysRevResearch.2.033429.
- [295] J. Hermann, J. Spencer, K. Choo, A. Mezzacapo, W. M. C. Foulkes, D. Pfau, G. Carleo and F. Noé, *Ab initio quantum chemistry with neural-network wavefunctions*, Nat. Rev. Chem. **7**(10), 692–709 (2023), doi:10.1038/s41570-023-00516-8.

- [296] S. B. Bravyi and A. Y. Kitaev, *Fermionic quantum computation*, Ann. Phys. **298**, 210 (2002), doi:10.1006/aphy.2002.6254.
- [297] P. Jordan and E. Wigner, *Über das Paulische Äquivalenzverbot*, Zeitschrift für Physik **47**, 631 (1928), doi:10.1007/BF01331938.
- [298] E. Zohar and J. I. Cirac, *Eliminating fermionic matter fields in lattice gauge theories*, Phys. Rev. B **98**, 075119 (2018), doi:10.1103/PhysRevB.98.075119.
- [299] U. Borla, R. Verresen, F. Grusdt and S. Moroz, *Confined phases of one-dimensional spinless fermions coupled to Z_2 gauge theory*, Phys. Rev. Lett. **124**, 120503 (2020), doi:10.1103/PhysRevLett.124.120503.
- [300] J. Nys and G. Carleo, *Variational solutions to fermion-to-qubit mappings in two spatial dimensions*, Quantum **6**, 833 (2022), doi:10.22331/q-2022-10-13-833.
- [301] T. D. Barrett, A. Malyshev and A. I. Lvovsky, *Autoregressive neural-network wavefunctions for ab initio quantum chemistry*, Nat. Mach. Intell. **4**(4), 351 (2022), doi:10.1038/s42256-022-00461-z.
- [302] B. Jonsson, B. Bauer and G. Carleo, *Neural-network states for the classical simulation of quantum computing* (2018), [arXiv:1808.05232](https://arxiv.org/abs/1808.05232).
- [303] M. Medvidović and G. Carleo, *Classical variational simulation of the quantum approximate optimization algorithm*, npj Quantum Inf. **7**, 101 (2021), doi:10.1038/s41534-021-00440-z.
- [304] E. Farhi, J. Goldstone and S. Gutmann, *A quantum approximate optimization algorithm* (2014), [arXiv:1411.4028](https://arxiv.org/abs/1411.4028).
- [305] M. P. Harrigan, K. J. Sung, M. Neeley, K. J. Satzinger, F. Arute, K. Arya, J. Atalaya, J. C. Bardin, R. Barends, S. Boixo and et al., *Quantum approximate optimization of non-planar graph problems on a planar superconducting processor*, Nat. Phys. **17**, 332–336 (2021), doi:10.1038/s41567-020-01105-y.
- [306] J. Carrasquilla, D. Luo, F. Pérez, A. Milsted, B. K. Clark, M. Volkovs and L. Aolita, *Probabilistic simulation of quantum circuits using a deep-learning architecture*, Phys. Rev. A **104**, 032610 (2021), doi:10.1103/PhysRevA.104.032610.
- [307] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser and I. Polosukhin, *Attention is all you need*, In *Adv. Neural. Inf. Process. Syst.* (2017), [arXiv:1706.03762](https://arxiv.org/abs/1706.03762).
- [308] H.-P. Breuer and F. Petruccione, *The Theory of Open Quantum Systems*, Oxford University Press, ISBN 9780198520634, doi:10.1093/acprof:oso/9780199213900.001.0001 (2007).

- [309] N. Yoshioka and R. Hamazaki, *Constructing neural stationary states for open quantum many-body systems*, Phys. Rev. B **99**, 214306 (2019), doi:10.1103/PhysRevB.99.214306.
- [310] A. Nagy and V. Savona, *Variational quantum Monte Carlo method with a neural-network ansatz for open quantum systems*, Phys. Rev. Lett. **122**, 250501 (2019), doi:10.1103/PhysRevLett.122.250501.
- [311] F. Vicentini, A. Biella, N. Regnault and C. Ciuti, *Variational neural-network ansatz for steady states in open quantum systems*, Phys. Rev. Lett. **122**, 250503 (2019), doi:10.1103/PhysRevLett.122.250503.
- [312] M. J. Hartmann and G. Carleo, *Neural-network approach to dissipative quantum many-body dynamics*, Phys. Rev. Lett. **122**, 250502 (2019), doi:10.1103/PhysRevLett.122.250502.
- [313] D. Luo, Z. Chen, J. Carrasquilla and B. K. Clark, *Autoregressive neural network for simulating open quantum systems via a probabilistic formulation*, Phys. Rev. Lett. **128**, 090501 (2022), doi:10.1103/PhysRevLett.128.090501.
- [314] M. Reh, M. Schmitt and M. Gärttner, *Time-dependent variational principle for open quantum systems with artificial neural networks*, Phys. Rev. Lett. **127**, 230501 (2021), doi:10.1103/PhysRevLett.127.230501.
- [315] F. Minganti, A. Biella, N. Bartolo and C. Ciuti, *Spectral theory of Liouvillians for dissipative phase transitions*, Phys. Rev. A **98**, 042118 (2018), doi:10.1103/PhysRevA.98.042118.
- [316] O. Gühne and G. Tóth, *Entanglement detection*, Physics Reports **474**(1), 1 (2009), doi:https://doi.org/10.1016/j.physrep.2009.02.004.
- [317] M. P. da Silva, O. Landon-Cardinal and D. Poulin, *Practical characterization of quantum devices without tomography*, Phys. Rev. Lett. **107**, 210404 (2011), doi:10.1103/PhysRevLett.107.210404.
- [318] A. Tavakoli, *Semi-device-independent certification of independent quantum state and measurement devices*, Phys. Rev. Lett. **125**, 150503 (2020), doi:10.1103/PhysRevLett.125.150503.
- [319] M. Kliesch and I. Roth, *Theory of quantum system certification*, PRX Quantum **2**, 010201 (2021), doi:10.1103/PRXQuantum.2.010201.
- [320] N. Friis, G. Vitagliano, M. Malik and M. Huber, *Entanglement certification from theory to experiment*, Nature Reviews Physics **1**(1), 72 (2019), doi:10.1038/s42254-018-0003-5.

- [321] J. Eisert, D. Hangleiter, N. Walk, I. Roth, D. Markham, R. Parekh, U. Chabaud and E. Kashefi, *Quantum certification and benchmarking*, Nature Reviews Physics **2**(7), 382 (2020), doi:10.1038/s42254-020-0186-4.
- [322] O. M. Sotnikov, I. A. Iakovlev, A. A. Iliasov, M. I. Katsnelson, A. A. Bagrov and V. V. Mazurenko, *Certification of quantum states with hidden structure of their bitstrings*, npj Quantum Information **8**(1), 41 (2022), doi:10.1038/s41534-022-00559-7.
- [323] S. Chen, J. Li, B. Huang and A. Liu, *Tight bounds for quantum state certification with incoherent measurements*, In *2022 IEEE 63rd Annual Symposium on Foundations of Computer Science (FOCS)*, pp. 1205–1213. IEEE Computer Society, Los Alamitos, CA, USA, doi:10.1109/FOCS54457.2022.00118 (2022).
- [324] A. Gočanin, I. Šupić and B. Dakić, *Sample-efficient device-independent quantum state verification and certification*, PRX Quantum **3**, 010317 (2022), doi:10.1103/PRXQuantum.3.010317.
- [325] E.-C. Boghiu, F. Hirsch, P.-S. Lin, M. T. Quintino and J. Bowles, *Device-independent and semi-device-independent entanglement certification in broadcast Bell scenarios*, SciPost Phys. Core **6**, 028 (2023), doi:10.21468/SciPostPhysCore.6.2.028.
- [326] D. Hangleiter, M. Kliesch, M. Schwarz and J. Eisert, *Direct certification of a class of quantum simulations*, Quantum Science and Technology **2**(1), 015004 (2017), doi:10.1088/2058-9565/2/1/015004.
- [327] I. Frérot, M. Fadel and M. Lewenstein, *Probing quantum correlations in many-body systems: a review of scalable methods*, Reports on Progress in Physics **86**(11), 114001 (2023), doi:10.1088/1361-6633/acf8d7.
- [328] U. Leonhardt, *Quantum-state tomography and discrete wigner function*, Phys. Rev. Lett. **74**, 4101 (1995), doi:10.1103/PhysRevLett.74.4101.
- [329] A. G. White, D. F. V. James, P. H. Eberhard and P. G. Kwiat, *Nonmaximally entangled states: Production, characterization, and utilization*, Phys. Rev. Lett. **83**, 3103 (1999), doi:10.1103/PhysRevLett.83.3103.
- [330] C. F. Roos, G. P. T. Lancaster, M. Riebe, H. Häffner, W. Hänsel, S. Gulde, C. Becher, J. Eschner, F. Schmidt-Kaler and R. Blatt, *Bell states of atoms with ultralong lifetimes and their tomographic state analysis*, Phys. Rev. Lett. **92**, 220402 (2004), doi:10.1103/PhysRevLett.92.220402.
- [331] H. Häffner, W. Hänsel, C. F. Roos, J. Benhelm, D. Chek-al kar, M. Chwalla, T. Körber, U. D. Rapol, M. Riebe, P. O. Schmidt, C. Becher, O. Gühne *et al.*,

- Scalable multiparticle entanglement of trapped ions*, Nature **438**(7068), 643 (2005), doi:10.1038/nature04279.
- [332] D. Gross, Y.-K. Liu, S. T. Flammia, S. Becker and J. Eisert, *Quantum state tomography via compressed sensing*, Phys. Rev. Lett. **105**, 150401 (2010), doi:10.1103/PhysRevLett.105.150401.
- [333] D. Gross, *Recovering low-rank matrices from few coefficients in any basis*, IEEE Transactions on Information Theory **57**(3), 1548 (2011), doi:10.1109/TIT.2011.2104999.
- [334] G. Tóth, W. Wieczorek, D. Gross, R. Krischek, C. Schwemmer and H. Weinfurter, *Permutationally invariant quantum tomography*, Phys. Rev. Lett. **105**, 250403 (2010), doi:10.1103/PhysRevLett.105.250403.
- [335] T. Moroder, P. Hyllus, G. Tóth, C. Schwemmer, A. Niggebaum, S. Gaile, O. Gühne and H. Weinfurter, *Permutationally invariant state reconstruction*, New Journal of Physics **14**(10), 105001 (2012), doi:10.1088/1367-2630/14/10/105001.
- [336] M. Cramer, M. B. Plenio, S. T. Flammia, R. Somma, D. Gross, S. D. Bartlett, O. Landon-Cardinal, D. Poulin and Y.-K. Liu, *Efficient quantum state tomography*, Nat. Commun. **1**(1) (2010), doi:10.1038/ncomms1147.
- [337] T. Baumgratz, D. Gross, M. Cramer and M. B. Plenio, *Scalable reconstruction of density matrices*, Phys. Rev. Lett. **111**, 020401 (2013), doi:10.1103/PhysRevLett.111.020401.
- [338] B. P. Lanyon, C. Maier, M. Holzäpfel, T. Baumgratz, C. Hempel, P. Jurcevic, I. Dhand, A. S. Buyskikh, A. J. Daley, M. Cramer, M. B. Plenio, R. Blatt *et al.*, *Efficient tomography of a quantum many-body system*, Nat. Phys. **13**(12), 1158 (2017), doi:10.1038/nphys4244.
- [339] A. Palmieri, E. Kovlakov, F. Bianchi, D. Yudin, S. Straupe, J. D. Biamonte and S. Kulik, *Experimental neural network enhanced quantum tomography*, npj Quantum Inf **6**, 20 (2020), doi:10.1038/s41534-020-0248-6.
- [340] C. Pan and J. Zhang, *Deep learning-based quantum state tomography with imperfect measurement*, International Journal of Theoretical Physics **61**(9) (2022), doi:10.1007/s10773-022-05209-4.
- [341] D. Koutný, L. Motka, Z. c. v. Hradil, J. Řeháček and L. L. Sánchez-Soto, *Neural-network quantum state tomography*, Phys. Rev. A **106**, 012409 (2022), doi:10.1103/PhysRevA.106.012409.

- [342] S. Ahmed, C. Sánchez Muñoz, F. Nori and A. F. Kockum, *Quantum state tomography with conditional generative adversarial networks*, Phys. Rev. Lett. **127**, 140502 (2021), doi:10.1103/PhysRevLett.127.140502.
- [343] H. Ma, Z. Sun, D. Dong, C. Chen and H. Rabitz, *Attention-based transformer networks for quantum state tomography* (2023), [arXiv:2305.05433](https://arxiv.org/abs/2305.05433).
- [344] A. M. Palmieri, G. Müller-Rigat, A. K. Srivastava, M. Lewenstein, G. Rajchel-Mieldzioć and M. Płodzień, *Enhancing quantum state tomography via resource-efficient attention-based neural networks*, Phys. Rev. Res. **6**, 033248 (2024), doi:10.1103/PhysRevResearch.6.033248.
- [345] G. Torlai, G. Mazzola, J. Carrasquilla, M. Troyer, R. Melko and G. Carleo, *Neural-network quantum state tomography*, Nat. Phys. **14**, 447–450 (2018), doi:10.1038/s41567-018-0048-5.
- [346] A. Szabó and C. Castelnovo, *Neural network wave functions and the sign problem*, Phys. Rev. Res. **2**, 033075 (2020), doi:10.1103/PhysRevResearch.2.033075.
- [347] T. Schmale, M. Reh and M. Gärttner, *Efficient quantum state tomography with convolutional neural networks*, npj Quantum Inf. **8**(1), 115 (2022), doi:10.1038/s41534-022-00621-4.
- [348] G. Torlai, B. Timar, E. P. L. van Nieuwenburg, H. Levine, A. Omran, A. Keesling, H. Bernien, M. Greiner, V. Vuletić, M. D. Lukin, R. G. Melko and M. Endres, *Integrating neural networks with a quantum simulator for state reconstruction*, Phys. Rev. Lett. **123**, 230504 (2019), doi:10.1103/PhysRevLett.123.230504.
- [349] S. Lohani, B. T. Kirby, M. Brodsky, O. Danaci and R. T. Glasser, *Machine learning assisted quantum state estimation*, Mach. Learn.: Sci. Technol. **1**(3), 035007 (2020), doi:10.1088/2632-2153/ab9a21.
- [350] S. Lohani, T. A. Searles, B. T. Kirby and R. T. Glasser, *On the experimental feasibility of quantum state reconstruction via machine learning*, IEEE Trans. Quantum Eng. **2**, 1 (2021), doi:10.1109/TQE.2021.3106958.
- [351] S. Lohani, J. M. Lukens, D. E. Jones, T. A. Searles, R. T. Glasser and B. T. Kirby, *Improving application performance with biased distributions of quantum states*, Phys. Rev. Res. **3**, 043145 (2021), doi:10.1103/PhysRevResearch.3.043145.
- [352] S. Lohani, J. M. Lukens, R. T. Glasser, T. A. Searles and B. T. Kirby, *Data-centric machine learning in quantum information science*, Mach. Learn.: Sci. Technol. **3**(4), 04LT01 (2022), doi:10.1088/2632-2153/ac9036.

- [353] O. Danaci, S. Lohani, B. T. Kirby and R. T. Glasser, *Machine learning pipeline for quantum state estimation with incomplete measurements*, Mach. Learn.: Sci. Technol. **2**(3), 035014 (2021), doi:10.1088/2632-2153/abe5f5.
- [354] S. Aaronson, *Shadow tomography of quantum states*, In *Proceedings of the 50th Annual ACM SIGACT Symposium on Theory of Computing*, STOC 2018, p. 325–338. Association for Computing Machinery, New York, NY, USA, ISBN 9781450355599, doi:10.1145/3188745.3188802 (2018).
- [355] S. Aaronson and G. N. Rothblum, *Gentle measurement of quantum states and differential privacy*, In *Proceedings of the 51st Annual ACM SIGACT Symposium on Theory of Computing*, STOC 2019, p. 322–333. Association for Computing Machinery, New York, NY, USA, ISBN 9781450367059, doi:10.1145/3313276.3316378 (2019).
- [356] J. B. Altepeter, D. F. James and P. G. Kwiat, *4 qubit quantum state tomography*, Quantum state estimation pp. 113–145 (2004).
- [357] R. O’Donnell and J. Wright, *Efficient quantum tomography*, In *Proceedings of the Forty-Eighth Annual ACM Symposium on Theory of Computing*, STOC ’16, p. 899–912. Association for Computing Machinery, New York, NY, USA, ISBN 9781450341325, doi:10.1145/2897518.2897544 (2016).
- [358] D. E. Koh and S. Grewal, *Classical Shadows With Noise*, Quantum **6**, 776 (2022), doi:10.22331/q-2022-08-16-776.
- [359] A. Elben, R. Kueng, H.-Y. R. Huang, R. van Bijnen, C. Kokail, M. Dalmonte, P. Calabrese, B. Kraus, J. Preskill, P. Zoller and B. Vermersch, *Mixed-state entanglement from local randomized measurements*, Phys. Rev. Lett. **125**, 200501 (2020), doi:10.1103/PhysRevLett.125.200501.
- [360] A. Elben, S. T. Flammia, H.-Y. Huang, R. Kueng, J. Preskill, B. Vermersch and P. Zoller, *The randomized measurement toolbox*, Nat. Rev. Phys. **5**(1), 9 (2023), doi:10.1038/s42254-022-00535-2.
- [361] K. Donatella, Z. Denis, A. Le Boité and C. Ciuti, *Dynamics with autoregressive neural quantum states: Application to critical quench dynamics*, Phys. Rev. A **108**, 022210 (2023), doi:10.1103/PhysRevA.108.022210.
- [362] A. Sinibaldi, C. Giuliani, G. Carleo and F. Vicentini, *Unbiasing time-dependent Variational Monte Carlo by projected quantum evolution*, Quantum **7**, 1131 (2023), doi:10.22331/q-2023-10-10-1131.
- [363] M. Kitagawa and M. Ueda, *Squeezed spin states*, Phys. Rev. A **47**, 5138 (1993), doi:10.1103/PhysRevA.47.5138.

- [364] D. J. Wineland, J. J. Bollinger, W. M. Itano and D. J. Heinzen, *Squeezed atomic states and projection noise in spectroscopy*, Phys. Rev. A **50**, 67 (1994), doi:10.1103/PhysRevA.50.67.
- [365] M. Płodzień, M. Kościelski, E. Witkowska and A. Sinatra, *Producing and storing spin-squeezed states and Greenberger-Horne-Zeilinger states in a one-dimensional optical lattice*, Phys. Rev. A **102**, 013328 (2020), doi:10.1103/PhysRevA.102.013328.
- [366] M. Płodzień, M. Lewenstein, E. Witkowska and J. Chwedeńczuk, *One-axis twisting as a method of generating many-body Bell correlations*, Phys. Rev. Lett. **129**, 250402 (2022), doi:10.1103/PhysRevLett.129.250402.
- [367] M. Płodzień, T. Wasak, E. Witkowska, M. Lewenstein and J. Chwedeńczuk, *Generation of scalable many-body bell correlations in spin chains with short-range two-body interactions*, Phys. Rev. Res. **6**, 023050 (2024), doi:10.1103/PhysRevResearch.6.023050.
- [368] T. Hernández Yanes, M. Płodzień, M. Mackoīt Sinkevičienė, G. Žlabys, G. Juzeliūnas and E. Witkowska, *One- and two-axis squeezing via laser coupling in an atomic Fermi-Hubbard model*, Phys. Rev. Lett. **129**, 090403 (2022), doi:10.1103/PhysRevLett.129.090403.
- [369] M. Dziurawiec, T. H. Yanes, M. Płodzień, M. Gajda, M. Lewenstein and E. Witkowska, *Accelerating many-body entanglement generation by dipolar interactions in the Bose-Hubbard model*, Phys. Rev. A **107**(1) (2023), doi:10.1103/PhysRevA.107.013311.
- [370] T. Hernández Yanes, G. Žlabys, M. Płodzień, D. Burba, M. M. Sinkevičienė, E. Witkowska and G. Juzeliūnas, *Spin squeezing in open Heisenberg spin chains*, Phys. Rev. B **108**, 104301 (2023), doi:10.1103/PhysRevB.108.104301.
- [371] C. Adams, G. Carleo, A. Lovato and N. Rocco, *Variational Monte Carlo calculations of $A \leq 4$ nuclei with an artificial neural-network correlator ansatz*, Phys. Rev. Lett. **127**, 022502 (2021), doi:10.1103/PhysRevLett.127.022502.
- [372] J. Bausch and F. Leditzky, *Quantum codes from neural networks*, New J. Phys. **22**(2), 023005 (2020), doi:10.1088/1367-2630/ab6cdd.
- [373] F. Vicentini, *Machine learning toolbox for quantum many body physics*, Nat. Rev. Phys. **3**, 156 (2021), doi:10.1038/s42254-021-00285-7.
- [374] G. Carleo, *Beijing lecture notes and code*, [Lecture Notes](#) (2017).

- [375] A. A. Melnikov, H. P. Nautrup, M. Krenn, V. Dunjko, M. Tiersch, A. Zeilinger and H. J. Briegel, *Active learning machine learns to create new quantum experiments*, Proc. Natl. Acad. Sci. U.S.A. **115**(6), 1221 (2018), doi:10.1073/pnas.1714936115.
- [376] A. Fawzi, M. Balog, A. Huang, T. Hubert, B. Romera-Paredes, M. Barekatin, A. Novikov, F. J. R. Ruiz, J. Schrittwieser, G. Swirszcz, D. Silver, D. Hassabis *et al.*, *Discovering faster matrix multiplication algorithms with reinforcement learning*, Nature **610**(7930), 47 (2022), doi:10.1038/s41586-022-05172-4.
- [377] D. J. Mankowitz, A. Michi, A. Zhernov, M. Gelmi, M. Selvi, C. Paduraru, E. Leurent, S. Iqbal, J.-B. Lespiau, A. Ahern, T. Köppe, K. Millikin *et al.*, *Faster sorting algorithms discovered using deep reinforcement learning*, Nature **618**(7964), 257 (2023), doi:10.1038/s41586-023-06004-9.
- [378] S. R. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, Bradford Book, ISBN 9780262352703, doi:10.5555/980651.980663 (2018).
- [379] R. S. Sutton, *Learning to predict by the methods of temporal differences*, Mach. Learn. **3**, 9 (1988), doi:10.1007/BF00115009.
- [380] G. A. Rummery and M. Niranjan, *On-line Q-learning using connectionist systems*, CUED/F-INFENG/TR 166, University of Cambridge, Department of Engineering (1994).
- [381] H. van Seijen, A. R. Mahmood, P. M. Pilarski, M. C. Machado and R. S. Sutton, *True online temporal-difference learning*, J. Mach. Learn. Res. **17**, 1 (2016), doi:10.48550/arXiv.1512.04087.
- [382] G. H. John, *When the best move isn't optimal: Q-learning with exploration*, In *Proc. 12th Nat. Conf. Artif. Intell. (Vol. 2)* (1994).
- [383] C. J. C. H. Watkins and P. Dayan, *Q-learning*, Mach. Learn. **8**, 279 (1992), doi:10.1007/BF00992698.
- [384] J. E. Smith and R. L. Winkler, *The optimizer's curse: Skepticism and postdecision surprise in decision analysis*, Manag. Sci. **52**, 311 (2006), doi:10.1287/mnsc.1050.0451.
- [385] S. Thrun and A. Schwartz, *Issues in using function approximation for reinforcement learning*, In *Proc. 4th Connectionist Models Summer School* (1993).
- [386] H. Van Hasselt, *Double Q-learning*, In *NIPS 2010 - Adv. Neural Inf. Process. Syst.* (2010).
- [387] L.-J. Lin, *Reinforcement Learning for Robots Using Neural Networks*, Ph.D. thesis, Carnegie Mellon University, USA, UMI Order No. GAX93-22750 (1992).

- [388] H. Van Hasselt, A. Guez and D. Silver, *Deep reinforcement learning with double Q-learning*, In *Proc. AAAI Conf. Artif. Intell.* (2016), [arXiv:1509.06461](#).
- [389] P. Marbach and J. N. Tsitsiklis, *Simulation-based optimization of Markov reward processes*, *IEEE Trans. Automat. Contr.* **46**, 191 (2001), doi:10.1109/9.905687.
- [390] R. S. Sutton, D. McAllester, S. Singh and Y. Mansour, *Policy gradient methods for reinforcement learning with function approximation*, In *NIPS 1999 - Adv. Neural Inf. Process. Syst.* (1999).
- [391] R. J. Williams, *Simple statistical gradient-following algorithms for connectionist reinforcement learning*, *Mach. Learn.* **8**, 229 (1992), doi:10.1007/BF00992696.
- [392] S. J. Rennie, E. Marcheret, Y. Mroueh, J. Ross and V. Goel, *Self-critical sequence training for image captioning*, In *Proc. IEEE Conf. Comput. Vision and Pattern Recognition*, doi:10.1109/CVPR.2017.131 (2017).
- [393] J. Schulman, P. Moritz, S. Levine, M. Jordan and P. Abbeel, *High-dimensional continuous control using generalized advantage estimation*, In *ICLR 2016 - Int. Conf. Learn. Represent.* (2016), [arXiv:1506.02438](#).
- [394] A. G. Barto, R. S. Sutton and C. W. Anderson, *Neuronlike adaptive elements that can solve difficult learning control problems*, *IEEE Trans. Syst. Man Cybern. Syst.* **5**, 834 (1983), doi:10.1109/TSMC.1983.6313077.
- [395] V. Konda and J. Tsitsiklis, *Actor-critic algorithms*, In *Adv. Neural Inf. Process. Syst.* (1999).
- [396] T. Degris, M. White and R. S. Sutton, *Off-policy actor-critic*, In *ICML 2012 - Conf. Mach. Learn.*, p. 179–186. Omnipress (2012), [arXiv:1205.4839](#).
- [397] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver and K. Kavukcuoglu, *Asynchronous methods for deep reinforcement learning*, In *ICML 2016 - 33th Int. Conf. Mach. Learn.*, vol. 48, pp. 1928–1937 (2016), [arXiv:1602.01783](#).
- [398] S.-i. Amari, *Natural gradient works efficiently in learning*, *Neural Comput.* **10**(2), 251 (1998), doi:10.1162/089976698300017746.
- [399] S. M. Kakade, *A natural policy gradient*, In *NIPS 2001 - Adv. Neural Inf. Process. Syst.* (2001).
- [400] J. Peters and S. Schaal, *Natural actor-critic*, *Neurocomputing* **71**(7), 1180 (2008), doi:10.1016/j.neucom.2007.11.026.

- [401] S. Bhatnagar, R. S. Sutton, M. Ghavamzadeh and M. Lee, *Natural actor-critic algorithms*, Automatica **45**(11), 2471 (2009), doi:10.1016/j.automatica.2009.07.008.
- [402] J. Schulman, S. Levine, P. Abbeel, M. Jordan and P. Moritz, *Trust region policy optimization*, In *ICML 2015 - Int. Conf. Mach. Learn.* (2015), [arXiv:1502.05477](#).
- [403] Y. Wu, E. Mansimov, R. B. Grosse, S. Liao and J. Ba, *Scalable trust-region method for deep reinforcement learning using Kronecker-factored approximation*, In *NIPS 2017 - Adv. Neural Inf. Process. Syst.* (2017), [arXiv:1708.05144](#).
- [404] J. Schulman, F. Wolski, P. Dhariwal, A. Radford and O. Klimov, *Proximal policy optimization algorithms* (2017), [arXiv:1707.06347](#).
- [405] H. J. Briegel and G. De las Cuevas, *Projective simulation for artificial intelligence*, Sci. Rep. **2**(1), 1 (2012), doi:10.1038/srep00400.
- [406] J. Mautner, A. Makmal, D. Manzano, M. Tiersch and H. J. Briegel, *Projective simulation for classical learning agents: A comprehensive investigation*, New Gener. Comput. **33**(1), 69 (2015), doi:10.1007/s00354-015-0102-0.
- [407] A. A. Melnikov, A. Makmal and H. J. Briegel, *Benchmarking projective simulation in navigation problems*, IEEE Access **6**, 64639 (2018), doi:10.1109/ACCESS.2018.2876494.
- [408] S. Jerbi, L. M. Trenkwalder, H. P. Nautrup, H. J. Briegel and V. Dunjko, *Quantum enhancements for deep reinforcement learning in large spaces*, PRX Quantum **2**(1), 010328 (2021), doi:10.1103/PRXQuantum.2.010328.
- [409] W. L. Boyajian, J. Clausen, L. M. Trenkwalder, V. Dunjko and H. J. Briegel, *On the convergence of projective-simulation-based reinforcement learning in Markov decision processes*, Quantum Mach. Intell. **2**(2), 1 (2020), doi:10.1007/s42484-020-00023-9.
- [410] A. A. Melnikov, A. Makmal, V. Dunjko and H. J. Briegel, *Projective simulation with generalization*, Sci. Rep. **7**(1), 1 (2017), doi:10.1038/s41598-017-14740-y.
- [411] B. Eva, K. Ried, T. Müller and H. J. Briegel, *How a minimal learning agent can infer the existence of unobserved variables in a complex environment*, Minds and Machines **33**(1), 185–219 (2022), doi:10.1007/s11023-022-09619-5.
- [412] M. Campbell, A. J. Hoane Jr and F.-h. Hsu, *Deep blue*, Artif. Intell. **134**(1-2), 57 (2002), doi:10.1016/S0004-3702(01)00129-1.
- [413] A. Yee and M. Alvarado, *Pattern recognition and Monte-Carlo tree search for Go gaming better automation*, In *IBERAMIA 2012 – Adv. Artif. Intell.*, doi:10.1007/978-3-642-34654-5_2 (2012).

- [414] R. Coulom, *Efficient selectivity and backup operators in Monte-Carlo tree search*, In *International conference on computers and games*, pp. 72–83. Springer, doi: 10.1007/978-3-540-75538-8_7 (2006).
- [415] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, Y. Chen, T. Lillicrap *et al.*, *Mastering the game of Go without human knowledge*, *Nature* **550**(7676), 354 (2017), doi: 10.1038/nature24270.
- [416] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez, M. Lanctot, L. Sifre, D. Kumaran, T. Graepel, T. Lillicrap, K. Simonyan *et al.*, *A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play*, *Science* **362**(6419), 1140 (2018), doi:10.1126/science.aar6404.
- [417] OpenAI, C. Berner, G. Brockman, B. Chan, V. Cheung, P. Dębiak, C. Dennison, D. Farhi, Q. Fischer, S. Hashme, C. Hesse, R. Józefowicz *et al.*, *Dota 2 with large scale deep reinforcement learning* (2019), [arXiv:1912.06680](https://arxiv.org/abs/1912.06680).
- [418] W. H. Guss, C. Codel, K. Hofmann, B. Houghton, N. Kuno, S. Milani, S. Mohanty, D. Perez Liebana, R. Salakhutdinov, N. Topin *et al.*, *The MineRL 2019 competition on sample efficient reinforcement learning using human priors* (2019), [arXiv:1904.10079](https://arxiv.org/abs/1904.10079).
- [419] J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, T. Lillicrap and D. Silver, *Mastering Atari, Go, chess and shogi by planning with a learned model*, *Nature* **588**(7839), 604 (2020), doi:10.1038/s41586-020-03051-4.
- [420] F. Marquardt, *Machine learning and quantum devices*, *SciPost Phys. Lect. Notes* p. 29 (2021), doi:10.21468/SciPostPhysLectNotes.29.
- [421] R. Porotti, A. Essig, B. Huard and F. Marquardt, *Deep reinforcement learning for quantum state preparation with weak nonlinear measurements*, *Quantum* **6**, 747 (2022), doi:10.22331/q-2022-06-28-747.
- [422] T. Fösel, P. Tighineanu, T. Weiss and F. Marquardt, *Reinforcement learning with neural networks for quantum feedback*, *Phys. Rev. X* **8**, 031084 (2018), doi: 10.1103/PhysRevX.8.031084.
- [423] S. Borah, B. Sarma, M. Kewming, G. J. Milburn and J. Twamley, *Measurement-based feedback quantum control with deep reinforcement learning for a double-well nonlinear potential*, *Phys. Rev. Lett.* **127**, 190403 (2021), doi:10.1103/PhysRevLett.127.190403.

- [424] V. Nguyen, S. B. Orbell, D. T. Lennon, H. Moon, F. Vigneau, L. C. Camenzind, L. Yu, D. M. Zumbühl, G. A. D. Briggs, M. A. Osborne, D. Sejdinovic and N. Ares, *Deep reinforcement learning for efficient measurement of quantum devices*, npj Quantum Inf. **7**(1), 100 (2021), doi:10.1038/s41534-021-00434-x.
- [425] J. Preskill, *Quantum computing in the NISQ era and beyond*, Quantum **2**, 79 (2018), doi:10.22331/q-2018-08-06-79.
- [426] T. Fösel, M. Yuezheng Niu, F. Marquardt and L. Li, *Quantum circuit optimization with deep reinforcement learning* (2021), [arXiv:2103.07585](#).
- [427] W. K. Wootters and W. H. Zurek, *A single quantum cannot be cloned*, Nature **299**(5886), 802 (1982), doi:10.1038/299802a0.
- [428] P. W. Shor, *Scheme for reducing decoherence in quantum computer memory*, Phys. Rev. A **52**, R2493 (1995), doi:10.1103/PhysRevA.52.R2493.
- [429] A. M. Steane, *Error correcting codes in quantum theory*, Phys. Rev. Lett. **77**, 793 (1996), doi:10.1103/PhysRevLett.77.793.
- [430] D. Gottesman, *An introduction to quantum error correction and fault-tolerant quantum computation* (2009), [arXiv:0904.2557](#).
- [431] R. Sweke, M. S. Kesselring, E. P. L. van Nieuwenburg and J. Eisert, *Reinforcement learning decoders for fault-tolerant quantum computation*, Mach. Learn.: Sci. Technol. **2**(2), 025005 (2021), doi:10.1088/2632-2153/abc609.
- [432] P. Andreasson, J. Johansson, S. Liljestrand and M. Granath, *Quantum error correction for the toric code using deep reinforcement learning*, Quantum **3**, 183 (2019), doi:10.22331/q-2019-09-02-183.
- [433] D. Fitzek, M. Eliasson, A. F. Kockum and M. Granath, *Deep Q-learning decoder for depolarizing noise on the toric code*, Phys. Rev. Res. **2**, 023230 (2020), doi:10.1103/PhysRevResearch.2.023230.
- [434] H. Théveniaut and E. van Nieuwenburg, *A NEAT Quantum Error Decoder*, SciPost Phys. **11**, 5 (2021), doi:10.21468/SciPostPhys.11.1.005.
- [435] M. Erhard, M. Krenn and A. Zeilinger, *Advances in high-dimensional quantum entanglement*, Nat. Rev. Phys. **2**(7), 365 (2020), doi:10.1038/s42254-020-0193-5.
- [436] M. Krenn, M. Malik, R. Fickler, R. Lapkiewicz and A. Zeilinger, *Automated search for new quantum experiments*, Phys. Rev. Lett. **116**, 090405 (2016), doi:10.1103/PhysRevLett.116.090405.

- [437] M. Krenn, J. S. Kottmann, N. Tischler and A. Aspuru-Guzik, *Conceptual understanding through efficient automated design of quantum optical experiments*, Phys. Rev. X **11**, 031044 (2021), doi:10.1103/PhysRevX.11.031044.
- [438] M. Krenn, M. Erhard and A. Zeilinger, *Computer-inspired quantum experiments*, Nat. Rev. Phys. **2**, 649 (2020), doi:10.1038/s42254-020-0230-4.
- [439] A. Peres, *Separability criterion for density matrices*, Phys. Rev. Lett. **77**(8), 1413 (1996), doi:10.1103/PhysRevLett.77.1413.
- [440] B. Requena, G. Muñoz Gil, M. Lewenstein, V. Dunjko and J. Tura, *Certificates of quantum many-body properties assisted by machine learning*, Phys. Rev. Res. **5**, 013097 (2023), doi:10.1103/PhysRevResearch.5.013097.
- [441] M. Bukov, A. G. R. Day, D. Sels, P. Weinberg, A. Polkovnikov and P. Mehta, *Reinforcement learning in different phases of quantum control*, Phys. Rev. X **8**, 031086 (2018), doi:10.1103/PhysRevX.8.031086.
- [442] M. Y. Niu, S. Boixo, V. N. Smelyanskiy and H. Neven, *Universal quantum control through deep reinforcement learning*, npj Quantum Inf. **5**(33), 1 (2019), doi:10.1038/s41534-019-0141-3.
- [443] K. A. McKiernan, E. Davis, M. S. Alam and C. Rigetti, *Automated quantum programming via reinforcement learning for combinatorial optimization* (2019), [arXiv:1908.08054](https://arxiv.org/abs/1908.08054).
- [444] Y.-H. Zhang, P.-L. Zheng, Y. Zhang and D.-L. Deng, *Topological quantum compiling with reinforcement learning*, Phys. Rev. Lett. **125**, 170501 (2020), doi:10.1103/PhysRevLett.125.170501.
- [445] Y. Baum, M. Amico, S. Howell, M. Hush, M. Liuzzi, P. Mundada, T. Merkh, A. R. Carvalho and M. J. Biercuk, *Experimental deep reinforcement learning for error-robust gate-set design on a superconducting quantum computer*, PRX Quantum **2**, 040324 (2021), doi:10.1103/PRXQuantum.2.040324.
- [446] C. Cao, Z. An, S.-Y. Hou, D. L. Zhou and B. Zeng, *Quantum imaginary time evolution steered by reinforcement learning*, Commun. Phys. **5**(57), 1 (2022), doi:10.1038/s42005-022-00837-y.
- [447] F. Metz and M. Bukov, *Self-correcting quantum many-body control using reinforcement learning with tensor networks*, Nat. Mach. Intell. **5**(7), 780 (2023), doi:10.1038/s42256-023-00687-5.
- [448] Y. Qiu, M. Zhuang, J. Huang and C. Lee, *Efficient and robust entanglement generation with deep reinforcement learning for quantum metrology*, New J. Phys. **24**(8), 083011 (2022), doi:10.1088/1367-2630/ac8285.

- [449] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra and M. Riedmiller, *Deterministic policy gradient algorithms*, In *ICML 2014 - Int. Conf. Mach. Learn.*, doi:10.5555/3044805.3044850 (2014).
- [450] S. Levine, *Reinforcement learning and control as probabilistic inference: Tutorial and review* (2018), [arXiv:1805.00909](#).
- [451] T. Haarnoja, A. Zhou, P. Abbeel and S. Levine, *Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor*, In *ICML 2018 - Int. Conf. Mach. Learn.* (2018), [arXiv:1801.01290](#).
- [452] A. Abdolmaleki, J. T. Springenberg, Y. Tassa, R. Munos, N. Heess and M. Riedmiller, *Maximum a posteriori policy optimisation* (2018), [arXiv:1806.06920](#).
- [453] J. Degraeve, F. Felici, J. Buchli, M. Neunert, B. Tracey, F. Carpanese, T. Ewalds, R. Hafner, A. Abdolmaleki, D. de las Casas, C. Donner, L. Fritz *et al.*, *Magnetic control of tokamak plasmas through deep reinforcement learning*, *Nature* **602**(7897), 414 (2022), doi:10.1038/s41586-021-04301-9.
- [454] V. V. Sivak, A. Eickbusch, H. Liu, B. Royer, I. Tsioutsios and M. H. Devoret, *Model-free quantum control with reinforcement learning*, *Phys. Rev. X* **12**, 011059 (2022), doi:10.1103/PhysRevX.12.011059.
- [455] V. V. Sivak, A. Eickbusch, B. Royer, S. Singh, I. Tsioutsios, S. Ganjam, A. Miano, B. L. Brock, A. Z. Ding, L. Frunzio, S. M. Girvin, R. J. Schoelkopf *et al.*, *Real-time quantum error correction beyond break-even*, *Nature* **616**(7955), 50 (2023), doi:10.1038/s41586-023-05782-6.
- [456] A. Karpathy, *Software 2.0*, [Medium](#), Accessed: 2022-04-08 (2017).
- [457] C. D. Schuman, T. E. Potok, R. M. Patton, J. D. Birdwell, M. E. Dean, G. S. Rose and J. S. Plank, *A survey of neuromorphic computing and neural networks in hardware* (2017), [arXiv:1808.05232](#).
- [458] K. Roy, A. Jaiswal and P. Panda, *Towards spike-based machine intelligence with neuromorphic computing*, *Nature* **575**(7784), 607 (2019), doi:10.1038/s41586-019-1677-2.
- [459] M. Innes, A. Edelman, K. Fischer, C. Rackauckas, E. Saba, V. B. Shah and W. Tebbutt, *A differentiable programming system to bridge machine learning and scientific computing* (2019), [arXiv:1907.07587](#).
- [460] S. G. Johnson, *Notes on adjoint methods for 18.335*, Tech. rep., MIT, [Introduction to Numerical Methods](#) (2021).

- [461] R. T. Chen, Y. Rubanova, J. Bettencourt and D. K. Duvenaud, *Neural ordinary differential equations*, In *NeurIPS 2018 - Adv. Neural Inf. Process. Syst.* (2018), [arXiv:1806.07366](#).
- [462] H.-J. Liao, J.-G. Liu, L. Wang and T. Xiang, *Differentiable programming tensor networks*, *Phys. Rev. X* **9**(3), 031041 (2019), doi:10.1103/PhysRevX.9.031041.
- [463] B.-B. Chen, Y. Gao, Y.-B. Guo, Y. Liu, H.-H. Zhao, H.-J. Liao, L. Wang, T. Xiang, W. Li and Z. Y. Xie, *Automatic differentiation for second renormalization of tensor networks*, *Phys. Rev. B* **101**, 220409 (2020), doi:10.1103/PhysRevB.101.220409.
- [464] G. Torlai, J. Carrasquilla, M. T. Fishman, R. G. Melko and M. P. A. Fisher, *Wave-function positivization via automatic differentiation*, *Phys. Rev. Res.* **2**, 032060 (2020), doi:10.1103/PhysRevResearch.2.032060.
- [465] J. Ingraham, A. Riesselman, C. Sander and D. Marks, *Learning protein structure with a differentiable simulator*, In *ICLR 2018 - Int. Conf. Learn. Represent.* (2018).
- [466] S. S. Schoenholz and E. D. Cubuk, *JAX, M.D.: A framework for differentiable physics*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:1912.04232](#).
- [467] T. Tamayo-Mendoza, C. Kreisbeck, R. Lindh and A. Aspuru-Guzik, *Automatic differentiation in quantum chemistry with applications to fully variational Hartree–Fock*, *ACS Cent. Sci.* **4**(5), 559 (2018), doi:10.1021/acscentsci.7b00586.
- [468] L. Zhao and E. Neuscamman, *Excited state mean-field theory without automatic differentiation*, *J. Chem. Phys.* **152**(20), 204112 (2020), doi:10.1063/5.0003438.
- [469] L. Li, S. Hoyer, R. Pederson, R. Sun, E. D. Cubuk, P. Riley, K. Burke *et al.*, *Kohn-Sham equations as regularizer: Building prior knowledge into machine-learned physics*, *Phys. Rev. Lett.* **126**(3), 036401 (2021), doi:10.1103/PhysRevLett.126.036401.
- [470] M. F. Kasim and S. M. Vinko, *Learning the exchange-correlation functional from nature with fully differentiable density functional theory*, *Phys. Rev. Lett.* **127**, 126403 (2021), doi:10.1103/PhysRevLett.127.126403.
- [471] A. S. Abbott, B. Z. Abbott, J. M. Turney and H. F. Schaefer, *Arbitrary-order derivatives of quantum chemical methods via automatic differentiation*, *J. Phys. Chem. Lett.* **12**(12), 3232 (2021), doi:10.1021/acs.jpcllett.1c00607.
- [472] M. F. Kasim, S. Lehtola and S. M. Vinko, *DQC: A Python program package for differentiable quantum chemistry*, *J. Chem. Phys.* **156**(8), 084801 (2022), doi:10.1063/5.0076202.

- [473] V. Bergholm, J. Izaac, M. Schuld, C. Gogolin, M. S. Alam, S. Ahmed, J. M. Arrazola, C. Blank, A. Delgado, S. Jahangiri, K. McKiernan, J. J. Meyer *et al.*, *PennyLane: Automatic differentiation of hybrid quantum-classical computations* (2020), [arXiv:1811.04968](#).
- [474] X. Zhang and G. K.-L. Chan, *Differentiable quantum chemistry with PySCF for molecules and materials at the mean-field level and beyond*, J. Chem. Phys. **157**(20) (2022), doi:10.1063/5.0118200, 204801.
- [475] N. Yoshikawa and M. Sumita, *Automatic differentiation for the direct minimization approach to the Hartree–Fock method*, J. Phys. Chem. A **126**(45), 8487 (2022), doi:10.1021/acs.jpca.2c05922, PMID: 36346835.
- [476] R. A. Vargas–Hernández, K. Jorner, R. Pollice and A. Aspuru–Guzik, *Inverse molecular design and parameter optimization with Hückel theory using automatic differentiation*, The Journal of Chemical Physics **158**(10) (2023), doi:10.1063/5.0137103.
- [477] N. Khaneja, T. Reiss, C. Kehlet, T. Schulte-Herbrüggen and S. J. Glaser, *Optimal control of coupled spin dynamics: design of NMR pulse sequences by gradient ascent algorithms*, J. Magn. Reson. **172**(2), 296 (2005), doi:10.1016/j.jmr.2004.11.004.
- [478] N. Leung, M. Abdelhafez, J. Koch and D. Schuster, *Speedup for quantum optimal control from automatic differentiation based on graphics processing units*, Phys. Rev. A **95**(4) (2017), doi:10.1103/PhysRevA.95.042318.
- [479] M. Abdelhafez, D. I. Schuster and J. Koch, *Gradient-based optimal control of open quantum systems using quantum trajectories and automatic differentiation*, Phys. Rev. A **99**, 052327 (2019), doi:10.1103/PhysRevA.99.052327.
- [480] H. Jirari, *Optimal population inversion of a single dissipative two-level system*, Eur. Phys. J. B **92**(12), 265 (2019), doi:10.1140/epjb/e2019-100378-x.
- [481] H. Jirari, *Time-optimal bang-bang control for the driven spin-boson system*, Phys. Rev. A **102**, 012613 (2020), doi:10.1103/PhysRevA.102.012613.
- [482] F. Schäfer, M. Kloc, C. Bruder and N. Lörch, *A differentiable programming method for quantum control*, Mach. Learn.: Sci. Technol. **1**(3), 035009 (2020), doi:10.1088/2632-2153/ab9802.
- [483] R. A. Vargas-Hernández, R. T. Q. Chen, K. A. Jung and P. Brumer, *Inverse design of dissipative quantum steady-states with implicit differentiation* (2020), [arXiv:2011.12808](#).

- [484] R. A. Vargas-Hernández, R. T. Q. Chen, K. A. Jung and P. Brumer, *Fully differentiable optimization protocols for non-equilibrium steady states*, New J. Phys. **23**(12), 123006 (2021), doi:10.1088/1367-2630/ac395e.
- [485] I. Khait, J. Carrasquilla and D. Segal, *Optimal control of quantum thermal machines using machine learning*, Phys. Rev. Res. **4**, L012029 (2022), doi:10.1103/PhysRevResearch.4.L012029.
- [486] L. Coopmans, D. Luo, G. Kells, B. K. Clark and J. Carrasquilla, *Protocol discovery for the quantum control of majoranas by differentiable programming and natural evolution strategies*, PRX Quantum **2**(2), 020332 (2021), doi:10.1103/PRXQuantum.2.020332.
- [487] F. Schäfer, P. Sekatski, M. Koppenhöfer, C. Bruder and M. Kloc, *Control of stochastic quantum dynamics by differentiable programming*, Mach. Learn.: Sci. Technol. **2**(3), 035004 (2021), doi:10.1088/2632-2153/abec22.
- [488] M. H. Goerz, S. C. Carrasco and V. S. Malinovsky, *Quantum optimal control via semi-automatic differentiation*, Quantum **6**, 871 (2022), doi:10.22331/q-2022-12-07-871.
- [489] X.-Z. Luo, J.-G. Liu, P. Zhang and L. Wang, *Yao. jl: Extensible, efficient framework for quantum algorithm design*, Quantum **4**, 341 (2020), doi:10.22331/q-2020-10-11-341.
- [490] O. Kyriienko, A. E. Paine and V. E. Elfving, *Solving nonlinear differential equations with differentiable quantum circuits*, Phys. Rev. A **103**(5), 052416 (2021), doi:10.1103/PhysRevA.103.052416.
- [491] P. Huembeli and A. Dauphin, *Characterizing the loss landscape of variational quantum circuits*, Quantum Sci. Technol. **6**(2), 025011 (2021), doi:10.1088/2058-9565/abdbc9.
- [492] A. G. Baydin, B. A. Pearlmutter, A. A. Radul and J. M. Siskind, *Automatic differentiation in machine learning: a survey*, J. Mach. Learn. Res. **18**(1), 5595–5637 (2018), doi:10.5555/3122009.3242010.
- [493] R. E. Wengert, *A simple automatic derivative evaluation program*, Commun. ACM **7**(8), 463 (1964), doi:10.1145/355586.364791.
- [494] A. Griewank and A. Walther, *Evaluating Derivatives: Principles and Techniques of Algorithmic Differentiation*, Society for Industrial and Applied Mathematics, ISBN 9780898716597, doi:10.1137/1.9780898717761 (2008).

- [495] S. Linnainmaa, *The representation of the cumulative rounding error of an algorithm as a Taylor expansion of the local rounding errors*, Ph.D. thesis, Univ. Helsinki, Finland, [Master's Thesis](#) (1970).
- [496] A. Griewank, *Who invented the reverse mode of differentiation*, [Documenta Math.](#), Accessed: 2022-04-01 (2012).
- [497] C. Rackauckas, *Parallel computing and scientific machine learning*, [18.337J/6.338J Lecture notes](#), MIT Lecture (2020).
- [498] Y. Ma, V. Dixit, M. Innes, X. Guo and C. Rackauckas, *A comparison of automatic differentiation and continuous sensitivity analysis for derivatives of differential equation solutions* (2021), [arXiv:1812.01892](#).
- [499] L. Wang, *Implementation of an inverse Schrödinger problem in JAX*, Available as Google Colab Notebook: https://colab.research.google.com/drive/1e1NFA-E1Th7nN_9-DzQjAag1H6bwZtVU?usp=sharing (2021).
- [500] H. Xie, J.-G. Liu and L. Wang, *Automatic differentiation of dominant eigensolver and its applications in quantum physics*, Phys. Rev. B **101**, 245139 (2020), doi:10.1103/PhysRevB.101.245139.
- [501] L. Wang, *Implementation of a quantum optimal control problem in JAX*, Accessed: 2022-03-11. Available as [Google Colab Notebook](#) (2021).
- [502] Q. Wang, R. Hu and P. Blonigan, *Least squares shadowing sensitivity analysis of chaotic limit cycle oscillations*, J. Comput. Phys **267**, 210 (2014), doi:10.1016/j.jcp.2014.03.002.
- [503] L. Metz, C. D. Freeman, S. S. Schoenholz and T. Kachman, *Gradients are not all you need* (2021), [arXiv:2111.05803](#).
- [504] W. S. Moses and V. Churavy, *Instead of rewriting foreign code for machine learning, automatically synthesize fast gradients*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2010.01709](#).
- [505] J.-G. Liu and T. Zhao, *Differentiate everything with a reversible embeded domain-specific language* (2020), [arXiv:2003.04617](#).
- [506] B. Silverman, *Density Estimation for Statistics and Data Analysis*, Chapman & Hall/CRC Monographs on Statistics & Applied Probability. Taylor & Francis, ISBN 9781315140919, doi:10.1201/9781315140919 (1998).
- [507] Z. Hradil, *Quantum-state estimation*, Phys. Rev. A **55**, R1561 (1997), doi:10.1103/PhysRevA.55.R1561.

- [508] M. Paris and J. Rehacek, *Quantum State Estimation*, Lecture Notes in Physics. Springer-Verlag Berlin/Heidelberg, ISBN 9783642061035, doi:10.1007/b98673 (2004).
- [509] Y. S. Teo, *Introduction to quantum-state estimation*, World Scientific, ISBN 9789814678865, doi:10.1142/9617 (2015).
- [510] S. Kullback and R. A. Leibler, *On information and sufficiency*, Ann. Math. Stat. **22**(1), 79 (1951), doi:10.1214/aoms/1177729694.
- [511] D. C. Hackett, C.-C. Hsieh, M. S. Albergo, D. Boyda, J.-W. Chen, K.-F. Chen, K. Cranmer, G. Kanwar and P. E. Shanahan, *Flow-based sampling for multimodal distributions in lattice field theory* (2021), [arXiv:2107.00734](#).
- [512] K. A. Nicoli, C. Anders, L. Funcke, T. Hartung, K. Jansen, P. Kessel, S. Nakajima and P. Stornati, *Machine learning of thermodynamic observables in the presence of mode collapse* (2021), [arXiv:2111.11303](#).
- [513] R. G. Melko, G. Carleo, J. Carrasquilla and J. I. Cirac, *Restricted Boltzmann machines in quantum physics*, Nat. Phys. **15**(9), 887 (2019), doi:10.1038/s41567-019-0545-1.
- [514] A. Van den Oord, N. Kalchbrenner, L. Espeholt, O. Vinyals, A. Graves *et al.*, *Conditional image generation with PixelCNN decoders*, In *NIPS 2016: Adv. Neural Inf. Process. Syst.* (2016), [arXiv:1606.05328](#).
- [515] D. P. Kingma and M. Welling, *An introduction to variational autoencoders*, Found. Trends Mach. Learn. **12**(4), 307 (2019), doi:10.1561/22000000056.
- [516] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville and Y. Bengio, *Generative adversarial nets*, In *NIPS 2014 - Adv. Neural Inf. Process. Syst.* (2014), [arXiv:1406.2661](#).
- [517] A. Creswell, T. White, V. Dumoulin, K. Arulkumaran, B. Sengupta and A. A. Bharath, *Generative adversarial networks: An overview*, IEEE Signal Process. Mag. **35**(1), 53 (2018), doi:10.1109/MSP.2017.2765202.
- [518] E. G. Tabak and E. Vanden-Eijnden, *Density estimation by dual ascent of the log-likelihood*, Commun. Math. Sci. **8**(1), 217 (2010), doi:10.4310/CMS.2010.v8.n1.a11.
- [519] G. Papamakarios, E. Nalisnick, D. J. Rezende, S. Mohamed and B. Lakshminarayanan, *Normalizing flows for probabilistic modeling and inference*, J. Mach. Learn. Res. **22**(57), 1 (2021), [arXiv:1912.02762](#).

- [520] I. Kobyzev, S. Prince and M. Brubaker, *Normalizing flows: An introduction and review of current methods*, IEEE Trans. Pattern Anal. Mach. Intell. **11**, 3964–3979 (2021), doi:10.1109/TPAMI.2020.2992934.
- [521] J. Ho, A. Jain and P. Abbeel, *Denoising diffusion probabilistic models*, In *NeurIPS 2020 - Adv. Neural Inf. Process Syst.* (2020), [arXiv:2006.11239](#).
- [522] L. Yang, Z. Zhang and S. Hong, *Diffusion models: A comprehensive survey of methods and applications* (2022), [arXiv:2209.00796](#).
- [523] F. Noé, S. Olsson, J. Köhler and H. Wu, *Boltzmann generators: Sampling equilibrium states of many-body systems with deep learning*, Science **365**(6457), eaaw1147 (2019), doi:10.1126/science.aaw1147.
- [524] K. A. Nicoli, C. J. Anders, L. Funcke, T. Hartung, K. Jansen, P. Kessel, S. Nakajima and P. Stornati, *Estimation of thermodynamic observables in lattice field theories with deep generative models*, Phys. Rev. Lett. **126**(3), 032001 (2021), doi:10.1103/PhysRevLett.126.032001.
- [525] M. S. Albergo, G. Kanwar and P. E. Shanahan, *Flow-based generative models for Markov chain Monte Carlo in lattice field theory*, Phys. Rev. D **100**, 034515 (2019), doi:10.1103/PhysRevD.100.034515.
- [526] M. Gabrié, G. M. Rotskoff and E. Vanden-Eijnden, *Adaptive Monte Carlo augmented with normalizing flows*, Proc. Natl. Acad. Sci. U.S.A. **119**(10), e2109420119 (2022), doi:10.1073/pnas.2109420119.
- [527] G. E. Hinton, *A practical guide to training restricted Boltzmann machines*, In G. Montavon, G. B. Orr and K.-R. Müller, eds., *Neural Networks: Tricks of the Trade: Second Edition*, Lecture Notes in Computer Science, pp. 599–619. Springer, Berlin, Heidelberg, ISBN 978-3-642-35289-8, doi:10.1007/978-3-642-35289-8_32 (2012).
- [528] M. Gabrié, E. W. Tramel and F. Krzakala, *Training restricted Boltzmann machines via the Thouless-Anderson-Palmer free energy*, In *NIPS 2015 - Adv. Neural Inf. Process. Syst.* (2015), [arXiv:1506.02914](#).
- [529] P. Ramachandran, T. L. Paine, P. Khorrami, M. Babaeizadeh, S. Chang, Y. Zhang, M. A. Hasegawa-Johnson, R. H. Campbell and T. S. Huang, *Fast generation for convolutional autoregressive models* (2017), [arXiv:1704.06001](#).
- [530] A. van den Oord, N. Kalchbrenner and K. Kavukcuoglu, *Pixel recurrent neural networks*, In *ICML 2016 - Int. Conf. Mach. Learn.* (2016), [arXiv:1601.06759](#).
- [531] M. Cristoforetti, G. Jurman, A. I. Nardelli and C. Furlanello, *Towards meaningful physics from generative models* (2019), [arXiv:1705.09524](#).

- [532] G. Kanwar, M. S. Albergo, D. Boyda, K. Cranmer, D. C. Hackett, S. Racaniere, D. J. Rezende and P. E. Shanahan, *Equivariant flow-based sampling for lattice gauge theory*, Phys. Rev. Lett. **125**(12), 121601 (2020), doi:10.1103/PhysRevLett.125.121601.
- [533] K. A. Nicoli, *Deep generative models for thermodynamics of spin systems and field theories*, Ph.D. thesis, Technische Universität Berlin, Fakultät IV, Maschinelles Lernen, doi:https://doi.org/10.14279/depositonce-17052 (2023).
- [534] L. Dinh, D. Krueger and Y. Bengio, *NICE: Non-linear independent components estimation*, In *ICLR 2015 - Int. Conf. Learn. Represent.* (2015), [arXiv:1410.8516](#).
- [535] L. Dinh, J. Sohl-Dickstein and S. Bengio, *Density estimation using real NVP*, In *ICLR 2017 - Int. Conf. Learn. Represent.* (2017), [arXiv:1605.08803](#).
- [536] D. P. Kingma and P. Dhariwal, *Glow: Generative flow with invertible 1x1 convolutions*, In *NeurIPS 2018 - Adv. Neural Inf. Process Syst.* (2018), [arXiv:1807.03039](#).
- [537] C. Durkan, A. Bekasov, I. Murray and G. Papamakarios, *Neural spline flows*, In *NeurIPS 2019 - Adv. Neural Inf. Process Syst.* (2019), [arXiv:1906.04032](#).
- [538] L. Grenioux, A. Oliviero Durmus, E. Moulines and M. Gabri  , *On sampling with approximate transport maps*, In *ICML 2023 - 40th Int. Conf. Mach. Learn.*, vol. 202, pp. 11698–11733. PMLR (2023), [arXiv:2302.04763](#).
- [539] T. M  ller, B. McWilliams, F. Rousselle, M. Gross and J. Nov  k, *Neural importance sampling*, ACM Trans. Graph. **38**(5), 1 (2019), doi:10.1145/3341156.
- [540] S. Bacchio, P. Kessel, S. Schaefer and L. Vaitl, *Learning trivializing gradient flows for lattice gauge theories*, Phys. Rev. D **107**, L051504 (2023), doi:10.1103/PhysRevD.107.L051504.
- [541] L. Del Debbio, J. M. Rossney and M. Wilson, *Machine learning trivializing maps: A first step towards understanding how flow-based samplers scale up* (2021), [arXiv:2112.15532](#).
- [542] L. Del Debbio, J. Marsh Rossney and M. Wilson, *Efficient modeling of trivializing maps for lattice ϕ^4 theory using normalizing flows: A first look at scalability*, Phys. Rev. D **104**, 094507 (2021), doi:10.1103/PhysRevD.104.094507.
- [543] R. Abbott, M. S. Albergo, A. Botev, D. Boyda, K. Cranmer, D. C. Hackett, A. G. D. G. Matthews, S. Racani  re, A. Razavi, D. J. Rezende, F. Romero-L  pez, P. E. Shanahan *et al.*, *Aspects of scaling and scalability for flow-based sampling of lattice qcd*, Eur. Phys. J. A **59**(11) (2023), doi:10.1140/epja/s10050-023-01154-w.

- [544] G. Kanwar, M. S. Albergo, D. Boyda, K. Cranmer, D. C. Hackett, S. Racanière, D. J. Rezende and P. E. Shanahan, *Equivariant flow-based sampling for lattice gauge theory*, Phys. Rev. Lett. **125**, 121601 (2020), doi:10.1103/PhysRevLett.125.121601.
- [545] D. Boyda, G. Kanwar, S. Racanière, D. J. Rezende, M. S. Albergo, K. Cranmer, D. C. Hackett and P. E. Shanahan, *Sampling using $SU(n)$ gauge equivariant flows*, Phys. Rev. D **103**, 074504 (2021), doi:10.1103/PhysRevD.103.074504.
- [546] J. Köhler, L. Klein and F. Noé, *Equivariant flows: exact likelihood generative learning for symmetric densities*, In *ICML 2020 - Int. Conf. Mach. Learn.* (2020), [arXiv:2006.02425](#).
- [547] V. G. Satorras, E. Hoogeboom, F. B. Fuchs, I. Posner and M. Welling, *$E(n)$ equivariant normalizing flows*, In *NeurIPS 2021 - Adv. Neural Inf. Process Syst.* (2021), [arXiv:2105.09016](#).
- [548] G. Jerfel, S. Wang, C. Wong-Fillman, K. A. Heller, Y. Ma and M. I. Jordan, *Variational refinement for importance sampling using the forward Kullback-Leibler divergence*, In *PLMR 2021 - Proc. Mach. Learn. Res.* (2021), [arXiv:2106.15980](#).
- [549] K. A. Nicoli, C. J. Anders, T. Hartung, K. Jansen, P. Kessel and S. Nakajima, *Detecting and mitigating mode-collapse for flow-based sampling of lattice field theories*, Phys. Rev. D **108**, 114501 (2023), doi:10.1103/PhysRevD.108.114501.
- [550] L. Vaitl, K. A. Nicoli, S. Nakajima and P. Kessel, *Gradients should stay on path: better estimators of the reverse- and forward KL divergence for normalizing flows*, Mach. Learn.: Sci. Technol. **3**(4), 045006 (2022), doi:10.1088/2632-2153/ac9455.
- [551] L. Vaitl, K. A. Nicoli, S. Nakajima and P. Kessel, *Path-gradient estimators for continuous normalizing flows*, In *PLMR 2022 - Proc. Mach. Learn. Res.* (2022), [arXiv:2206.09016](#).
- [552] M. Arbel, A. Matthews and A. Doucet, *Annealed flow transport Monte Carlo*, In *PLMR 2021 - Proc. Mach. Learn. Res.* (2021), [arXiv:2102.07501](#).
- [553] L. I. Midgley, V. Stimper, G. N. Simm, B. Schölkopf and J. M. Hernández-Lobato, *Flow annealed importance sampling bootstrap* (2022), [arXiv:2208.01893](#).
- [554] A. Matthews, M. Arbel, D. J. Rezende and A. Doucet, *Continual repeated annealed flow transport Monte Carlo*, In *PLMR 2022 - Proc. Mach. Learn. Res.* (2022), [arXiv:2201.13117](#).
- [555] L. Wang, *Generative models for physicists*, Tech. rep., Institute of Physics, Chinese Academy of Sciences, [GitHub.io](#) (2018).

- [556] M. S. Albergo, G. Kanwar, S. Racanière, D. J. Rezende, J. M. Urban, D. Boyda, K. Cranmer, D. C. Hackett and P. E. Shanahan, *Flow-based sampling for fermionic lattice field theories*, Phys. Rev. D **104**, 114507 (2021), doi:10.1103/PhysRevD.104.114507.
- [557] E. Lustig, O. Yair, R. Talmon and M. Segev, *Identifying topological phase transitions in experiments using manifold learning*, Phys. Rev. Lett. **125**(12), 127401 (2020), doi:10.1103/PhysRevLett.125.127401.
- [558] E. Greplova, C. Gold, B. Kratochwil, T. Davatz, R. Pisoni, A. Kurzmann, P. Rickhaus, M. H. Fischer, T. Ihn and S. D. Huber, *Fully automated identification of two-dimensional material samples*, Phys. Rev. Appl. **13**(6), 064017 (2020), doi:10.1103/PhysRevApplied.13.064017.
- [559] R. Durrer, B. Kratochwil, J. V. Koski, A. J. Landig, C. Reichl, W. Wegscheider, T. Ihn and E. Greplova, *Automated tuning of double quantum dots into specific charge states using neural networks*, Phys. Rev. Appl. **13**(5), 054019 (2020), doi:10.1103/PhysRevApplied.13.054019.
- [560] E. Greplova and S. Huber group, [GitHub repository](#) to “Fully automated search for 2D material samples” (2019).
- [561] P. Mostosi, H. Schindelin, P. Kollmannsberger and A. Thorn, *Haruspex: A neural network for the automatic identification of oligonucleotides and protein secondary structure in cryo-electron microscopy maps*, Angew. Chem. Int. Ed. **59**(35), 14788 (2020), doi:10.1002/anie.202000421.
- [562] K. Nolte, Y. Gao, S. Stäb, P. Kollmannsberger and A. Thorn, *Detecting ice artefacts in processed macromolecular diffraction data with machine learning*, Acta Crystallogr. D **78**(2), 187 (2022), doi:10.1107/S205979832101202X.
- [563] A. U. Lode, R. Lin, M. Büttner, L. Papariello, C. Lévesque, R. Chitra, M. C. Tsatsos, D. Jaksch and P. Mognini, *Optimized observable readout from single-shot images of ultracold atoms via machine learning*, Phys. Rev. A **104**(4), L041301 (2021), doi:10.1103/PhysRevA.104.L041301.
- [564] R. Lin, C. Georges, J. Klinder, P. Mognini, M. Büttner, A. U. Lode, R. Chitra, A. Hemmerich and H. Kefler, *Mott transition in a cavity-boson system: A quantitative comparison between theory and experiment*, SciPost Phys. **11**(2), 030 (2021), doi:10.21468/SciPostPhys.11.2.030.
- [565] R. Lin, P. Mognini, L. Papariello, M. C. Tsatsos, C. Lévesque, S. E. Weiner, E. Fasshauer, R. Chitra and A. U. Lode, *MCTDH-X: The multiconfigurational time-dependent Hartree method for indistinguishable particles software*, Quantum Sci. Technol. **5**(2), 024004 (2020), doi:10.1088/2058-9565/ab788b.

- [566] J. Zhang, G. Pagano, P. W. Hess, A. Kyprianidis, P. Becker, H. Kaplan, A. V. Gorshkov, Z.-X. Gong and C. Monroe, *Observation of a many-body dynamical phase transition with a 53-qubit quantum simulator*, Nature **551**(7682), 601 (2017), doi:10.1038/nature24654.
- [567] H. Bernien, S. Schwartz, A. Keesling, H. Levine, A. Omran, H. Pichler, S. Choi, A. S. Zibrov, M. Endres, M. Greiner *et al.*, *Probing many-body dynamics on a 51-atom quantum simulator*, Nature **551**(7682), 579 (2017), doi:10.1038/nature24622.
- [568] B. Chiaro, C. Neill, A. Bohrdt, M. Filippone, F. Arute, K. Arya, R. Babbush, D. Bacon, J. Bardin, R. Barends, S. Boixo, D. Buell *et al.*, *Direct measurement of nonlocal interactions in the many-body localized phase*, Phys. Rev. Res. **4**, 013148 (2022), doi:10.1103/PhysRevResearch.4.013148.
- [569] M. Rispoli, A. Lukin, R. Schittko, S. Kim, M. E. Tai, J. Léonard and M. Greiner, *Quantum critical behaviour at the many-body localization transition*, Nature **573**(7774), 385 (2019), doi:10.1038/s41586-019-1527-2.
- [570] A. Valenti, G. Jin, J. Léonard, S. D. Huber and E. Greplova, *Scalable Hamiltonian learning for large-scale out-of-equilibrium quantum dynamics*, Phys. Rev. A **105**, 023302 (2022), doi:10.1103/PhysRevA.105.023302.
- [571] A. Gresch, L. Bittel and M. Kliesch, *Scalable approach to many-body localization via quantum data* (2022), [arXiv:2202.08853](https://arxiv.org/abs/2202.08853).
- [572] V. Gebhart, R. Santagati, A. A. Gentile, E. M. Gauger, D. Craig, N. Ares, L. Banchi, F. Marquardt, L. Pezzè and C. Bonato, *Learning quantum systems*, Nat. Rev. Phys. **5**(3), 141 (2023), doi:10.1038/s42254-022-00552-1.
- [573] A. Cervera-Lierta, M. Krenn and A. Aspuru-Guzik, *Design of quantum optical experiments with logic artificial intelligence*, Quantum **6**, 836 (2022), doi:10.22331/q-2022-10-13-836.
- [574] D. Flam-Shepherd, T. C. Wu, X. Gu, A. Cervera-Lierta, M. Krenn and A. Aspuru-Guzik, *Learning interpretable representations of entanglement in quantum optics experiments using deep generative models*, Nat. Mach. Intell. **4**(6), 544–554 (2022), doi:10.1038/s42256-022-00493-5.
- [575] R. D. King, J. Rowland, S. G. Oliver, M. Young, W. Aubrey, E. Byrne, M. Liakata, M. Markham, P. Pir, L. N. Soldatova, A. Sparkes, K. E. Whelan *et al.*, *The automation of science*, Science **324**(5923), 85 (2009), doi:10.1126/science.1165620.
- [576] F. Häse, L. M. Roch and A. Aspuru-Guzik, *Next-generation experimentation with self-driving laboratories*, Trends Chem. **1**(3), 282 (2019), doi:10.1016/j.trechm.2019.02.007.

- [577] A. A. Gentile, B. Flynn, S. Knauer, N. Wiebe, S. Paesani, C. E. Granade, J. G. Rarity, R. Santagati and A. Laing, *Learning models of quantum systems from experiments*, Nat. Phys. **17**(7), 837 (2021), doi:10.1038/s41567-021-01201-7.
- [578] T. E. O’Brien, L. B. Ioffe, Y. Su, D. Fushman, H. Neven, R. Babbush and V. Smelyanskiy, *Quantum computation of molecular structure using data from challenging-to-classically-simulate nuclear magnetic resonance experiments*, PRX Quantum **3**, 030345 (2022), doi:10.1103/PRXQuantum.3.030345.
- [579] N. M. van Esbroeck, D. T. Lennon, H. Moon, V. Nguyen, F. Vigneau, L. C. Camenzind, L. Yu, D. M. Zumbühl, G. A. D. Briggs, D. Sejdinovic and N. Ares, *Quantum device fine-tuning using unsupervised embedding learning*, New J. Phys. **22**(9), 095003 (2020), doi:10.1088/1367-2630/abb64c.
- [580] B. Severin, D. T. Lennon, L. C. Camenzind, F. Vigneau, F. Fedele, D. Jirovec, A. Ballabio, D. Chrastina, G. Isella, M. de Kruijf, M. J. Carballido, S. Svab *et al.*, *Cross-architecture tuning of silicon and sige-based quantum devices using machine learning*, Sci. Rep. **14**(1) (2024), doi:10.1038/s41598-024-67787-z.
- [581] J. P. Zwolak, T. McJunkin, S. S. Kalantre, S. F. Neyens, E. MacQuarrie, M. A. Eriksson and J. M. Taylor, *Ray-based framework for state identification in quantum dot devices*, PRX Quantum **2**, 020335 (2021), doi:10.1103/PRXQuantum.2.020335.
- [582] A. Dawid, N. Bigagli, D. W. Savin and S. Will, *Automated graph-based detection of quantum control schemes: Application to molecular laser cooling*, Phys. Rev. Res. **7**, 013135 (2025), doi:10.1103/PhysRevResearch.7.013135.
- [583] N. Wiebe, A. Kapoor and K. M. Svore, *Quantum algorithms for nearest-neighbor methods for supervised and unsupervised learning*, Quantum Inf. Comput. **15**(3–4), 316–356 (2015), doi:10.26421/QIC15.3-4-7.
- [584] P. Raccuglia, K. C. Elbert, P. D. F. Adler, C. Falk, M. B. Wenny, A. Mollo, M. Zeller, S. A. Friedler, J. Schrier and A. J. Norquist, *Machine-learning-assisted materials discovery using failed experiments*, Nature **533**(7601), 73 (2016), doi:10.1038/nature17439.
- [585] L. Zdeborová, *Understanding deep learning is also a job for physicists*, Nat. Phys. **16**(6), 602 (2020), doi:10.1038/s41567-020-0929-2.
- [586] T. M. Cover, *Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition*, IEEE Trans. Comput. **EC-14**(3), 326 (1965), doi:10.1109/PGEC.1965.264137.

- [587] E. Gardner, *Maximum storage capacity in neural networks*, EPL **4**(4), 481 (1987), doi:10.1209/0295-5075/4/4/016.
- [588] D. J. Amit, H. Gutfreund and H. Sompolinsky, *Storing infinite numbers of patterns in a spin-glass model of neural networks*, Phys. Rev. Lett. **55**(14), 1530 (1985), doi:10.1103/PhysRevLett.55.1530.
- [589] B. Derrida, E. Gardner and A. Zippelius, *An exactly solvable asymmetric neural network model*, EPL **4**(2), 167 (1987), doi:10.1209/0295-5075/4/2/007.
- [590] B. Derrida and J. P. Nadal, *Learning and forgetting on asymmetric, diluted neural networks*, J. Stat. Phys. **49**(5-6), 993 (1987), doi:10.1007/BF01017556.
- [591] C. Peterson, *A mean field theory learning algorithm for neural networks*, [Complex Syst.](#) **1**, 995 (1987).
- [592] W. Krauth and M. Mézard, *Storage capacity of memory networks with binary couplings*, J. Phys. **50**(20), 3057 (1989), doi:10.1051/jphys:0198900500200305700.
- [593] G. Györgyi, *First-order transition to perfect generalization in a neural network with binary synapses*, Phys. Rev. A **41**(12), 7097 (1990), doi:10.1103/PhysRevA.41.7097.
- [594] M. Oppen and D. Haussler, *Generalization performance of Bayes optimal classification algorithm for learning a perceptron*, Phys. Rev. Lett. **66**(20), 2677 (1991), doi:10.1103/PhysRevLett.66.2677.
- [595] D. Sherrington and S. Kirkpatrick, *Solvable model of a spin-glass*, Phys. Rev. Lett. **35**(26), 1792 (1975), doi:10.1103/PhysRevLett.35.1792.
- [596] M. Mézard, G. Parisi and M. A. Virasoro, *SK model: The replica solution without replicas*, EPL **1**(2), 77 (1986), doi:10.1209/0295-5075/1/2/006.
- [597] F. Barahona, *On the computational complexity of Ising spin glass models*, J. Phys. A: Math. Gen. **15**, 3241 (1982), doi:10.1088/0305-4470/15/10/028.
- [598] C. Fan, M. Shen, Z. Nussinov, Z. Liu, Y. Sun and Y.-Y. Liu, *Searching for spin glass ground states through deep reinforcement learning*, Nat. Commun. **14**(1) (2023), doi:10.1038/s41467-023-36363-w.
- [599] S. F. Edwards and P. W. Anderson, *Theory of spin glasses*, J. Phys. F: Met. Phys. **5**, 965 (1975), doi:10.1088/0305-4608/5/5/017.
- [600] D. J. Thouless, P. W. Anderson and R. G. Palmer, *Solution of “Solvable model of a spin glass”*, Philos. Mag. **35**(3), 593 (1977), doi:10.1080/14786437708235992.

- [601] M. Talagrand, *The Parisi formula*, Ann. Math. **163**(1), 221 (2006), doi:10.4007/annals.2006.163.221.
- [602] D. Panchenko, *Introduction to the SK model*, Current Developments in Mathematics **2014**(1), 231 (2014), doi:10.4310/cdm.2014.v2014.n1.a4.
- [603] T. Castellani and A. Cavagna, *Spin-glass theory for pedestrians*, J. Stat. Mech. p. P05012 (2005), doi:10.1088/1742-5468/2005/05/P05012.
- [604] M. Gabri  , *Mean-field inference methods for neural networks*, J. Phys. A: Math. Theor. **53**(22), 223002 (2020), doi:10.1088/1751-8121/ab7f65.
- [605] J. Barbier, F. Krzakala, N. Macris, L. Miolane and L. Zdeborov  , *Optimal errors and phase transitions in high-dimensional generalized linear models*, Proc. Natl. Acad. Sci. U.S.A. **116**(12), 5451 (2019), doi:10.1073/pnas.1802705116.
- [606] S. Rangan, *Generalized approximate message passing for estimation with random linear mixing*, In *2011 IEEE International Symposium on Information Theory Proceedings*. IEEE, doi:10.1109/isit.2011.6033942 (2011).
- [607] L. Zdeborov   and F. Krzakala, *Statistical physics of inference: thresholds and algorithms*, Adv. Phys. **65**(5), 453 (2016), doi:10.1080/00018732.2016.1211393.
- [608] R. Monasson and R. Zecchina, *Learning and generalization theories of large committee machines*, Mod. Phys. Lett. B **09**(30), 1887 (1995), doi:10.1142/s0217984995001868.
- [609] B. Aubin, A. Maillard, J. Barbier, F. Krzakala, N. Macris and L. Zdeborov  , *The committee machine: computational to statistical gaps in learning a two-layers neural network*, J. Stat. Mech. Theor. Exp. **2019**(12), 124023 (2019), doi:10.1088/1742-5468/ab43d2.
- [610] A. Rahimi and B. Recht, *Random features for large-scale kernel machines*, In *NIPS 2007 - Adv. Neural Inf. Process. Syst.* (2007).
- [611] A. Rahimi and B. Recht, *Weighted sums of random kitchen sinks: replacing minimization with randomization in learning*, In *NIPS 2008 - Adv. Neural Inf. Process. Syst.* (2008).
- [612] H. Schwarze and J. Hertz, *Generalization in fully connected committee machines*, EPL **21**(7), 786 (1993), doi:10.1209/0295-5075/21/7/012.
- [613] H. Schwarze, *Learning a rule in a multilayer neural network*, J. Phys. A: Math. Gen. **26**(21), 5781 (1993), doi:10.1088/0305-4470/26/21/017.

- [614] F. Gerace, B. Loureiro, F. Krzakala, M. Mézard and L. Zdeborová, *Generalisation error in learning with random features and the hidden manifold model*, J. Stat. Mech. **2021**(12), 124013 (2021), doi:10.1088/1742-5468/ac3ae6.
- [615] S. D’Ascoli, M. Gabrié, L. Sagun and G. Biroli, *More data or more parameters? Investigating the effect of data structure on generalization*, In *NeurIPS 2021 - Adv. Neural Inf. Process. Syst.* (2021), [arXiv:2103.05524](#).
- [616] S. Goldt, M. S. Advani, A. M. Saxe, F. Krzakala and L. Zdeborová, *Dynamics of stochastic gradient descent for two-layer neural networks in the teacher-student setup*, J. Stat. Mech. Theor. Exp. **2020**(12), 1 (2020), doi:10.1088/1742-5468/abc61e.
- [617] M. Biehl and P. Riegler, *On-line learning with a perceptron*, EPL **28**(7), 525 (1994), doi:10.1209/0295-5075/28/7/012.
- [618] M. Biehl and H. Schwarze, *Learning by on-line gradient descent*, J. Phys. A: Math. Gen. **28**(3), 643 (1995), doi:10.1088/0305-4470/28/3/018.
- [619] S. Goldt, B. Loureiro, G. Reeves, F. Krzakala, M. Mézard and L. Zdeborová, *The Gaussian equivalence of generative models for learning with shallow neural networks* (2020), [arXiv:2006.14709](#).
- [620] F. Mignacco, F. Krzakala, P. Urbani and L. Zdeborová, *Dynamical mean-field theory for stochastic gradient descent in Gaussian mixture classification*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2006.06098](#).
- [621] M. Lewenstein, *Quantum perceptrons*, J. Mod. Opt. **41**(12), 2491 (1994), doi:10.1080/09500349414552331.
- [622] A. Gratsea, V. Kasper and M. Lewenstein, *Storage properties of a quantum perceptron* (2021), [arXiv:2111.08414](#).
- [623] M. Lewenstein, A. Gratsea, A. Riera-Campeny, A. Aloy, V. Kasper and A. Sanpera, *Storage capacity and learning capability of quantum neural networks*, Quantum Sci. Technol. **6**(4), 045002 (2021), doi:10.1088/2058-9565/ac070f.
- [624] A. Gratsea and P. Huembeli, *Exploring quantum perceptron and quantum neural network structures with a teacher-student scheme*, Quantum Mach. Intell. **4**(1), 2 (2022), doi:10.1007/s42484-021-00058-6.
- [625] Y. Feng and Y. Tu, *Phases of learning dynamics in artificial neural networks in the absence or presence of mislabeled data*, Mach. Learn.: Sci. Technol. **2**(4), 043001 (2021), doi:10.1088/2632-2153/abf5b9.

- [626] A. Decelle, C. Furtlehner and B. Seoane, *Equilibrium and non-equilibrium regimes in the learning of restricted Boltzmann machines*, In *NeurIPS 2021 - Adv. Neural Process. Syst.* (2021), [arXiv:2103.05524](#).
- [627] H.-S. Zhong, H. Wang, Y.-H. Deng, M.-C. Chen, L.-C. Peng, Y.-H. Luo, J. Qin, D. Wu, X. Ding, Y. Hu *et al.*, *Quantum computational advantage using photons*, *Science* **370**(6523), 1460 (2020), doi:10.1126/science.abe8770.
- [628] L. S. Madsen, F. Laudenbach, M. F. Askarani, F. Rortais, T. Vincent, J. F. F. Bulmer, F. M. Miatto, L. Neuhaus, L. G. Helt, M. J. Collins, A. E. Lita, T. Gerrits *et al.*, *Quantum computational advantage with a programmable photonic processor*, *Nature* **606**(7912), 75 (2022), doi:10.1038/s41586-022-04725-x.
- [629] F. Arute, K. Arya, R. Babbush, D. Bacon, J. C. Bardin, R. Barends, R. Biswas, S. Boixo, F. G. Brandao, D. A. Buell *et al.*, *Quantum supremacy using a programmable superconducting processor*, *Nature* **574**(7779), 505 (2019), doi:10.1038/s41586-019-1666-5.
- [630] C. D. Bruzewicz, J. Chiaverini, R. McConnell and J. M. Sage, *Trapped-ion quantum computing: Progress and challenges*, *Appl. Phys. Rev.* **6**(2), 021314 (2019), doi:10.1063/1.5088164, [arXiv:https://doi.org/10.1063/1.5088164](#).
- [631] M. Saffman, *Quantum computing with atomic qubits and Rydberg interactions: progress and challenges*, *J. Phys. B: At. Mol. Opt. Phys.* **49**(20), 202001 (2016), doi:10.1088/0953-4075/49/20/202001.
- [632] L. Henriët, L. Beguin, A. Signoles, T. Lahaye, A. Browaeys, G.-O. Reymond and C. Jurczak, *Quantum computing with neutral atoms*, *Quantum* **4**, 327 (2020), doi:10.22331/q-2020-09-21-327.
- [633] Y. Liu, S. Arunachalam and K. Temme, *A rigorous and robust quantum speed-up in supervised machine learning*, *Nat. Phys.* **17**(9), 1013 (2021), doi:10.1038/s41567-021-01287-z.
- [634] J. Herrmann, S. M. Llima, A. Remm, P. Zapletal, N. A. McMahon, C. Scarato, F. Swiadek, C. K. Andersen, C. Hellings, S. Krinner *et al.*, *Realizing quantum convolutional neural networks on a superconducting quantum processor to recognize quantum phases*, *Nat. Commun.* **13**(1), 4144 (2022), doi:10.1038/s41467-022-31679-5.
- [635] H.-Y. Huang, M. Broughton, J. Cotler, S. Chen, J. Li, M. Mohseni, H. Neven, R. Babbush, R. Kueng, J. Preskill *et al.*, *Quantum advantage in learning from experiments*, *Science* **376**(6598), 1182 (2022), doi:10.1126/science.abn7293.

- [636] M. Gong, H.-L. Huang, S. Wang, C. Guo, S. Li, Y. Wu, Q. Zhu, Y. Zhao, S. Guo, H. Qian, Y. Ye, C. Zha *et al.*, *Quantum neuronal sensing of quantum many-body states on a 61-qubit programmable superconducting processor*, Sci. Bull. **68**(9), 906 (2023), doi:<https://doi.org/10.1016/j.scib.2023.04.003>.
- [637] L. Hales and S. Hallgren, *An improved quantum Fourier transform algorithm and applications*, In *FOCS 2000 - 41st Annu. IEEE Symp. Found. Comput. Sci.*, pp. 515–525, doi:10.1109/SFCS.2000.892139 (2000).
- [638] P. Shor, *Algorithms for quantum computation: discrete logarithms and factoring*, In *FOCS 1994 - 35th Annu. IEEE Symp. Found. Comput. Sci.*, pp. 124–134, doi:10.1109/SFCS.1994.365700 (1994).
- [639] A. Y. Kitaev, *Quantum measurements and the Abelian stabilizer problem* (1995), [arXiv:quant-ph/9511026](https://arxiv.org/abs/quant-ph/9511026).
- [640] A. W. Harrow, A. Hassidim and S. Lloyd, *Quantum algorithm for linear systems of equations*, Phys. Rev. Lett. **103**, 150502 (2009), doi:10.1103/PhysRevLett.103.150502.
- [641] P. Rebentrost, M. Mohseni and S. Lloyd, *Quantum support vector machine for big data classification*, Phys. Rev. Lett. **113**, 130503 (2014), doi:10.1103/PhysRevLett.113.130503.
- [642] Z. Li, X. Liu, N. Xu and J. Du, *Experimental realization of a quantum support vector machine*, Phys. Rev. Lett. **114**, 140504 (2015), doi:10.1103/PhysRevLett.114.140504.
- [643] N. Wiebe, D. Braun and S. Lloyd, *Quantum algorithm for data fitting*, Phys. Rev. Lett. **109**, 050505 (2012), doi:10.1103/PhysRevLett.109.050505.
- [644] A. Gilyén, S. Lloyd and E. Tang, *Quantum-inspired low-rank stochastic regression with logarithmic dependence on the dimension* (2018), [arXiv:1811.04909](https://arxiv.org/abs/1811.04909).
- [645] A. Ekert and R. Jozsa, *Quantum computation and Shor’s factoring algorithm*, Rev. Mod. Phys. **68**, 733 (1996), doi:10.1103/RevModPhys.68.733.
- [646] C. M. Dawson and M. A. Nielsen, *The Solovay-Kitaev algorithm* (2005), [arXiv:quant-ph/0505030](https://arxiv.org/abs/quant-ph/0505030).
- [647] A. Morvan, B. Villalonga, X. Mi, S. Mandrà, A. Bengtsson, P. V. Klimov, Z. Chen, S. Hong, C. Erickson, I. K. Drozdov, J. Chau, G. Laun *et al.*, *Phase transitions in random circuit sampling*, Nature **634**(8033), 328–333 (2024), doi:10.1038/s41586-024-07998-6.

- [648] D. Bluvstein, S. J. Evered, A. A. Geim, S. H. Li, H. Zhou, T. Manovitz, S. Ebadi, M. Cain, M. Kalinowski, D. Hangleiter, J. P. Bonilla Ataides, N. Maskara *et al.*, *Logical quantum processor based on reconfigurable atom arrays*, Nature **626**(7997), 58–65 (2023), doi:10.1038/s41586-023-06927-3.
- [649] Y. Y. Atas, J. Zhang, R. Lewis, A. Jahanpour, J. F. Haase and C. A. Muschik, *$SU(2)$ hadrons on a quantum computer via a variational approach*, Nat. Commun. **12**(1) (2021), doi:10.1038/s41467-021-26825-4.
- [650] K. Temme, S. Bravyi and J. M. Gambetta, *Error mitigation for short-depth quantum circuits*, Phys. Rev. Lett. **119**, 180509 (2017), doi:10.1103/PhysRevLett.119.180509.
- [651] S. Endo, S. C. Benjamin and Y. Li, *Practical quantum error mitigation for near-future applications*, Phys. Rev. X **8**(3) (2018), doi:10.1103/PhysRevX.8.031027.
- [652] L. Funcke, T. Hartung, K. Jansen, S. Kühn, P. Stornati and X. Wang, *Measurement error mitigation in quantum computers through classical bit-flip correction*, Phys. Rev. A **105**, 062404 (2022), doi:10.1103/PhysRevA.105.062404.
- [653] A. D. Córcoles, E. Magesan, S. J. Srinivasan, A. W. Cross, M. Steffen, J. M. Gambetta and J. M. Chow, *Demonstration of a quantum error detection code using a square lattice of four superconducting qubits*, Nat. Commun. **6**(1), 6979 (2015), doi:10.1038/ncomms7979.
- [654] V. Havlíček, A. D. Córcoles, K. Temme, A. W. Harrow, A. Kandala, J. M. Chow and J. M. Gambetta, *Supervised learning with quantum-enhanced feature spaces*, Nature **567**(7747), 209 (2019), doi:10.1038/s41586-019-0980-2.
- [655] M. Schuld and N. Killoran, *Quantum machine learning in feature Hilbert spaces*, Phys. Rev. Lett. **122**, 040504 (2019), doi:10.1103/PhysRevLett.122.040504.
- [656] C. M. Wilson, J. S. Otterbach, N. Tezak, R. S. Smith, A. M. Polloreno, P. J. Karalekas, S. Heidel, M. S. Alam, G. E. Crooks and M. P. da Silva, *Quantum kitchen sinks: An algorithm for machine learning on near-term quantum computers* (2018), [arXiv:1806.08321](https://arxiv.org/abs/1806.08321).
- [657] J. Dai and R. V. Krems, *Quantum Gaussian process model of potential energy surface for a polyatomic molecule*, J. Chem. Phys. **156**(18), 184802 (2022), doi:10.1063/5.0088821.
- [658] *Quantum feature maps and kernels*, chapter of [the Qiskit textbook](#) “Introduction to Quantum Computing”, Accessed: 2022-03-02.

- [659] E. Tang, *Quantum principal component analysis only achieves an exponential speedup because of its state preparation assumptions*, Phys. Rev. Lett. **127**(6), 060503 (2021), doi:10.1103/PhysRevLett.127.060503.
- [660] J. M. Kübler, S. Buchholz and B. Schölkopf, *The inductive bias of quantum kernels*, In *NeurIPS 2021 - Adv. Neural Inf. Process. Syst.*, pp. 12661–12673 (2021), [arXiv:2106.03747](#).
- [661] T. Haug, C. N. Self and M. Kim, *Quantum machine learning of large datasets using randomized measurements*, Mach. Learn.: Sci. Technol. **4**(1), 015005 (2023), doi:10.1088/2632-2153/acb0b4.
- [662] J. Liu, F. Tacchino, J. R. Glick, L. Jiang and A. Mezzacapo, *Representation learning via quantum neural tangent kernels*, PRX Quantum **3**, 030323 (2022), doi:10.1103/PRXQuantum.3.030323.
- [663] E. Torabian and R. V. Krems, *Compositional optimization of quantum circuits for quantum kernels of support vector machines*, Phys. Rev. Res. **5**, 013211 (2023), doi:10.1103/PhysRevResearch.5.013211.
- [664] A. Peruzzo, J. McClean, P. Shadbolt, M.-H. Yung, X.-Q. Zhou, P. J. Love, A. Aspuru-Guzik and J. L. O’Brien, *A variational eigenvalue solver on a photonic quantum processor*, Nat. Comm. **5**(1) (2014), doi:10.1038/ncomms5213.
- [665] L. Funcke, T. Hartung, K. Jansen, S. Kühn and P. Stornati, *Dimensional expressivity analysis of parametric quantum circuits*, Quantum **5**, 422 (2021), doi:10.22331/q-2021-03-29-422.
- [666] A. Gresch and M. Kliesch, *Guaranteed efficient energy estimation of quantum many-body Hamiltonians using ShadowGrouping* (2023), [arXiv:2301.03385](#).
- [667] J. Li, X. Yang, X. Peng and C.-P. Sun, *Hybrid quantum-classical approach to quantum optimal control*, Phys. Rev. Lett. **118**, 150503 (2017), doi:10.1103/PhysRevLett.118.150503.
- [668] A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster and J. I. Latorre, *Data re-uploading for a universal quantum classifier*, Quantum **4**, 226 (2020), doi:10.22331/q-2020-02-06-226.
- [669] I. Cong, S. Choi and M. D. Lukin, *Quantum convolutional neural networks*, Nat. Phys. **15**(12), 1273–1278 (2019), doi:10.1038/s41567-019-0648-8.
- [670] M. Schuld, *Supervised quantum machine learning models are kernel methods* (2021), [arXiv:2101.11020](#).

- [671] S. Jerbi, L. J. Fiderer, H. Poulsen Nautrup, J. M. Kübler, H. J. Briegel and V. Dunjko, *Quantum machine learning beyond kernel methods*, Nat. Commun. **14**(1), 517 (2023), doi:10.1038/s41467-023-36159-y.
- [672] J. Bausch, *Recurrent quantum neural networks*, In *NeurIPS 2020 - Adv. Neural Inf. Process. Syst.* (2020), [arXiv:2006.14619](#).
- [673] S. Jerbi, C. Gyurik, S. Marshall, H. Briegel and V. Dunjko, *Parametrized quantum policies for reinforcement learning*, In *NeurIPS 2021 - Adv. Neural Inf. Process. Syst.*, pp. 28362–28375 (2021), [arXiv:2103.05577](#).
- [674] A. Skolik, S. Jerbi and V. Dunjko, *Quantum agents in the Gym: a variational quantum algorithm for deep Q-learning*, Quantum **6**, 720 (2022), doi:10.22331/q-2022-05-24-720.
- [675] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang and W. Zaremba, *OpenAI Gym* (2016), [arXiv:1606.01540](#).
- [676] J. Romero, J. P. Olson and A. Aspuru-Guzik, *Quantum autoencoders for efficient compression of quantum data*, Quantum Sci. Technol. **2**(4), 045001 (2017), doi:10.1088/2058-9565/aa8072.
- [677] D. Bondarenko and P. Feldmann, *Quantum autoencoders to denoise quantum data*, Phys. Rev. Lett. **124**(13) (2020), doi:10.1103/PhysRevLett.124.130502.
- [678] D. F. Locher, L. Cardarelli and M. Müller, *Quantum Error Correction with Quantum Autoencoders*, Quantum **7**, 942 (2023), doi:10.22331/q-2023-03-09-942.
- [679] G. Verdon, J. Marks, S. Nanda, S. Leichenauer and J. Hidary, *Quantum Hamiltonian-based models and the variational quantum thermalizer algorithm* (2019), [arXiv:1910.02071](#).
- [680] S. Lloyd and C. Weedbrook, *Quantum generative adversarial learning*, Phys. Rev. Lett. **121**, 040502 (2018), doi:10.1103/PhysRevLett.121.040502.
- [681] P.-L. Dallaire-Demers and N. Killoran, *Quantum generative adversarial networks*, Phys. Rev. A **98**, 012324 (2018), doi:10.1103/PhysRevA.98.012324.
- [682] J.-G. Liu and L. Wang, *Differentiable learning of quantum circuit Born machines*, Phys. Rev. A **98**, 062324 (2018), doi:10.1103/PhysRevA.98.062324.
- [683] B. Coyle, D. Mills, V. Danos and E. Kashefi, *The Born supremacy: quantum advantage and training of an Ising Born machine*, npj Quantum Inf. **6**(1) (2020), doi:10.1038/s41534-020-00288-9.

- [684] M. Benedetti, D. Garcia-Pintos, O. Perdomo, V. Leyton-Ortega, Y. Nam and A. Perdomo-Ortiz, *A generative modeling approach for benchmarking and training shallow quantum circuits*, npj Quantum Inf. **5**(1) (2019), doi:10.1038/s41534-019-0157-8.
- [685] L. Viola and S. Lloyd, *Dynamical suppression of decoherence in two-state quantum systems*, Phys. Rev. A **58**, 2733 (1998), doi:10.1103/PhysRevA.58.2733.
- [686] F. Kleißler, A. Lazariev and S. Arroyo-Camejo, *Universal, high-fidelity quantum gates based on superadiabatic, geometric phases on a solid-state spin-qubit at room temperature*, npj Quantum Inf. **4**(1) (2018), doi:10.1038/s41534-018-0098-7.
- [687] M. Taherkhani, M. Willatzen, E. V. Denning, I. E. Protsenko and N. Gregersen, *High-fidelity optical quantum gates based on type-II double quantum dots in a nanowire*, Phys. Rev. B **99**, 165305 (2019), doi:10.1103/PhysRevB.99.165305.
- [688] E. Zahedinejad, J. Ghosh and B. C. Sanders, *High-fidelity single-shot toffoli gate via quantum control*, Phys. Rev. Lett. **114**, 200502 (2015), doi:10.1103/PhysRevLett.114.200502.
- [689] D. Yu, H. Wang, D. Ma, X. Zhao and J. Qian, *Adiabatic and high-fidelity quantum gates with hybrid Rydberg-Rydberg interactions*, Opt. Express **27**(16), 23080 (2019), doi:10.1364/OE.27.023080.
- [690] F. Haddadfarshi and F. Mintert, *High fidelity quantum gates of trapped ions in the presence of motional heating*, New J. Phys. **18**(12), 123007 (2016), doi:10.1088/1367-2630/18/12/123007.
- [691] S. Li, J. Xue, T. Chen and Z. Xue, *High-fidelity geometric quantum gates with short paths on superconducting circuits*, Adv. Quantum Technol. **4**(5), 2000140 (2021), doi:10.1002/qute.202000140.
- [692] J. R. McClean, S. Boixo, V. N. Smelyanskiy, R. Babbush and H. Neven, *Barren plateaus in quantum neural network training landscapes*, Nat. Commun. **9**(1), 1 (2018), doi:10.1038/s41467-018-07090-4.
- [693] M. Cerezo, A. Sone, T. Volkoff, L. Cincio and P. J. Coles, *Cost function dependent barren plateaus in shallow parametrized quantum circuits*, Nat. Commun. **12**(1), 1 (2021), doi:10.1038/s41467-021-21728-w.
- [694] L. Bittel and M. Kliesch, *Training variational quantum algorithms is NP-hard*, Phys. Rev. Lett. **127**, 120502 (2021), doi:10.1103/PhysRevLett.127.120502.
- [695] S. Sim, P. D. Johnson and A. Aspuru-Guzik, *Expressibility and entangling capability of parameterized quantum circuits for hybrid quantum-classical algorithms*, Adv. Quantum Technol. **2**(12), 1900070 (2019), doi:10.1002/qute.201900070.

- [696] L. Bittel, S. Gharibian and M. Kliesch, *The optimal depth of variational quantum algorithms is QCMA-hard to approximate*, In *38th Comput. Complexity Conf. (CCC 2023)*, vol. 264, pp. 34:1–34:24, ISBN 978-3-95977-282-2, doi:10.4230/LIPIcs.CCC.2023.34 (2023), [arXiv:2211.12519](#).
- [697] A. Y. Kitaev, *Quantum computations: algorithms and error correction*, Russ. Math. Surv. **52**(6), 1191 (1997), doi:10.1070/rm1997v052n06abeh002155.
- [698] M. S. Rudolph, S. Sim, A. Raza, M. Stechly, J. R. McClean, E. R. Anschuetz, L. Serrano and A. Perdomo-Ortiz, *ORQVIZ: Visualizing high-dimensional landscapes in variational quantum algorithms* (2021), [arXiv:2111.04695](#).
- [699] J. Eisert, *Entangling power and quantum circuit complexity*, Phys. Rev. Lett. **127**, 020501 (2021), doi:10.1103/PhysRevLett.127.020501.
- [700] H.-Y. Huang, R. Kueng and J. Preskill, *Information-theoretic bounds on quantum advantage in machine learning*, Phys. Rev. Lett. **126**, 190505 (2021), doi:10.1103/PhysRevLett.126.190505.
- [701] K. Bharti, A. Cervera-Lierta, T. H. Kyaw, T. Haug, S. Alperin-Lea, A. Anand, M. Degroote, H. Heimonen, J. S. Kottmann, T. Menke *et al.*, *Noisy intermediate-scale quantum algorithms*, Rev. Mod. Phys. **94**(1), 015004 (2022), doi:10.1103/RevModPhys.94.015004.
- [702] G. Munoz-Gil, G. Volpe, M. A. Garcia-March, E. Aghion, A. Argun, C. B. Hong, T. Bland, S. Bo, J. A. Conejero, N. Firbas, O. Garibo i Orts, A. Gentili *et al.*, *Objective comparison of methods to decode anomalous diffusion*, Nat. Commun. **12**(1), 6253 (2021), doi:10.1038/s41467-021-26320-w.
- [703] G. Muñoz-Gil, M. A. Garcia-March, C. Manzo, J. D. Martín-Guerrero and M. Lewenstein, *Single trajectory characterization via machine learning*, New J. Phys. **22**(1), 013010 (2020), doi:10.1088/1367-2630/ab6065.
- [704] G. Munoz-Gil, C. Romero-Aristizabal, N. Mateos, F. Campelo, L. I. de Llobet-Cucalon, M. Beato, M. Lewenstein, M. Garcia-Parajo and J. A. Torreno-Pina, *Particle flow modulates growth dynamics and nanoscale-arrested growth of transcription factor condensates in living cells*, bioRxiv (2022), doi:10.1101/2022.01.11.475940.
- [705] H. B. Moss and R.-R. Griffiths, *Gaussian process molecule property prediction with FlowMO* (2020), [arXiv:2010.01118](#).
- [706] A. Glielmo, Y. Rath, G. Csányi, A. De Vita and G. H. Booth, *Gaussian process states: A data-driven representation of quantum many-body physics*, Phys. Rev. X **10**, 041026 (2020), doi:10.1103/PhysRevX.10.041026.

- [707] K. Choo, T. Neupert and G. Carleo, *Two-dimensional frustrated $J_1 - J_2$ model studied with neural network quantum states*, Phys. Rev. B **100**(12) (2019), doi:10.1103/PhysRevB.100.125124.
- [708] M. Secor, A. V. Soudackov and S. Hammes-Schiffer, *Artificial neural networks as propagators in quantum dynamics*, J. Phys. Chem. Lett. **12**(43), 10654 (2021), doi:10.1021/acs.jpcllett.1c03117.
- [709] V. Havlicek, *Amplitude Ratios and Neural Network Quantum States*, Quantum **7**, 938 (2023), doi:10.22331/q-2023-03-02-938.
- [710] J. Yao, L. Lin and M. Bukov, *Reinforcement learning for many-body ground-state preparation inspired by counterdiabatic driving*, Phys. Rev. X **11**, 031070 (2021), doi:10.1103/PhysRevX.11.031070.
- [711] H. P. Nautrup, N. Delfosse, V. Dunjko, H. J. Briegel and N. Friis, *Optimizing quantum error correction codes with reinforcement learning*, Quantum **3**, 215 (2019), doi:10.22331/q-2019-12-16-215.
- [712] P. Peng, X. Huang, C. Yin, L. Joseph, C. Ramanathan and P. Cappellaro, *Deep reinforcement learning for quantum hamiltonian engineering*, Phys. Rev. Appl. **18**, 024033 (2022), doi:10.1103/PhysRevApplied.18.024033.
- [713] J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Žídek, A. Potapenko *et al.*, *Highly accurate protein structure prediction with AlphaFold*, Nature **596**(7873), 583 (2021), doi:10.1038/s41586-021-03819-2.
- [714] M. Varadi, S. Anyango, M. Deshpande, S. Nair, C. Natassia, G. Yordanova, D. Yuan, O. Stroe, G. Wood, A. Laydon, A. Žídek, T. Green *et al.*, *AlphaFold protein structure database: massively expanding the structural coverage of protein-sequence space with high-accuracy models*, Nucleic Acids Res. **50**(D1), D439 (2021), doi:10.1093/nar/gkab1061.
- [715] A. Davies, P. Veličković, L. Buesing, S. Blackwell, D. Zheng, N. Tomašev, R. Tanburn, P. Battaglia, C. Blundell, A. Juhász, M. Lackenby, G. Williamson *et al.*, *Advancing mathematics by guiding human intuition with AI*, Nature **600**(7887), 70 (2021), doi:10.1038/s41586-021-04086-x.
- [716] T. Kriváchy, Y. Cai, D. Cavalcanti, A. Tavakoli, N. Gisin and N. Brunner, *A neural network oracle for quantum nonlocality problems in networks*, npj Quantum Inf. **6**, 70 (2020), doi:10.1038/s41534-020-00305-x.
- [717] A. Pozas-Kerstjens, N. Gisin and M.-O. Renou, *Proofs of network quantum nonlocality in continuous families of distributions*, Phys. Rev. Lett. **130**, 090201 (2023), doi:10.1103/PhysRevLett.130.090201.

- [718] A. Pozas-Kerstjens, G. Muñoz-Gil, E. Piñol, M. Á. García-March, A. Acín, M. Lewenstein and P. R. Grzybowski, *Efficient training of energy-based models via spin-glass control*, Mach. Learn.: Sci. Technol. **2**(2), 025026 (2021), doi:10.1088/2632-2153/abe807.
- [719] L. G. Wright, T. Onodera, M. M. Stein, T. Wang, D. T. Schachter, Z. Hu and P. L. McMahon, *Deep physical neural networks trained with backpropagation*, Nature **601**(7894), 549 (2022), doi:10.1038/s41586-021-04223-6.
- [720] K. Wagner and D. Psaltis, *Optical neural networks: an introduction by the feature editors*, Appl. Opt. **32**(8), 1261 (1993), doi:10.1364/AO.32.001261.
- [721] Y. Zuo, B. Li, Y. Zhao, Y. Jiang, Y.-C. Chen, P. Chen, G.-B. Jo, J. Liu and S. Du, *All-optical neural network with nonlinear activation functions*, Optica **6**(9), 1132 (2019), doi:10.1364/OPTICA.6.001132.
- [722] X. Sui, Q. Wu, J. Liu, Q. Chen and G. Gu, *A review of optical neural networks*, IEEE Access **8**, 70773 (2020), doi:10.1109/ACCESS.2020.2987333.
- [723] H. Zhang and e. a. Gu, *An optical neural chip for implementing complex-valued neural network*, Nat. Commun. **12**(1), 457 (2021), doi:10.1038/s41467-020-20719-7.
- [724] H. e. a. Zhang, *Efficient on-chip training of optical neural networks using genetic algorithm*, ACS Photonics **8**(6), 1662 (2021), doi:10.1021/acsp Photonics.1c00035.
- [725] X. Xu, M. Tan, B. Corcoran, J. Wu, A. Boes, T. G. Nguyen, S. T. Chu, B. E. Little, D. G. Hicks, R. Morandotti, A. Mitchell and D. J. Moss, *11 TOPS photonic convolutional accelerator for optical neural networks*, Nature **589**(7840), 44 (2021), doi:10.1038/s41586-020-03063-0.
- [726] J. Liu, Q. Wu, X. Sui, Q. Chen, G. Gu, L. Wang and S. Li, *Research progress in optical neural networks: theory, applications and developments*, Photonix **2**(1), 5 (2021), doi:10.1186/s43074-021-00026-0.
- [727] T. Wang, S.-Y. Ma, L. G. Wright, T. Onodera, B. C. Richard and P. L. McMahon, *An optical neural network using less than 1 photon per multiplication*, Nat. Commun. **13**(1), 123 (2022), doi:10.1038/s41467-021-27774-8.
- [728] H. Xu, S. Ghosh, M. Matuszewski and T. C. Liew, *Universal self-correcting computing with disordered exciton-polariton neural networks*, Phys. Rev. Appl. **13**, 064074 (2020), doi:10.1103/PhysRevApplied.13.064074.
- [729] D. Ballarini, A. Gianfrate, R. Panico, A. Opala, S. Ghosh, L. Dominici, V. Ardizzone, M. De Giorgi, G. Lerario, G. Gigli, T. C. H. Liew, M. Matuszewski *et al.*,

- Polaritonic neuromorphic computing outperforms linear classifiers*, Nano Lett. **20**(5), 3506 (2020), doi:10.1021/acs.nanolett.0c00435.
- [730] M. Matuszewski, A. Opala, R. Mirek, M. Furman, M. Król, K. Tyszka, T. Liew, D. Ballarini, D. Sanvitto, J. Szczytko and B. Piętko, *Energy-efficient neural network inference with microcavity exciton polaritons*, Phys. Rev. Appl. **16**, 024045 (2021), doi:10.1103/PhysRevApplied.16.024045.
- [731] R. Mirek, A. Opala, P. Comaron, M. Furman, M. Król, K. Tyszka, B. Serebnyński, D. Ballarini, D. Sanvitto, T. C. H. Liew, W. Pacuski, J. Suffczyński *et al.*, *Neuromorphic binarized polariton networks*, Nano Lett. **21**(9), 3715 (2021), doi:10.1021/acs.nanolett.0c04696.
- [732] D. Zvyagintseva, H. Sigurdsson, V. K. Kozin, I. Iorsh, I. A. Shelykh, V. Ulyantsev and O. Kyriienko, *Machine learning of phase transitions in nonlinear polariton lattices*, Commun. Phys. **5**(1), 8 (2022), doi:10.1038/s42005-021-00755-5.
- [733] J. J. Hopfield, *Neural networks and physical systems with emergent collective computational abilities*, Proc. Natl. Acad. Sci. U.S.A. **79**(8), 2554 (1982), doi:10.1073/pnas.79.8.2554.
- [734] P. Rotondo, M. Marcuzzi, J. P. Garrahan, I. Lesanovsky and M. Müller, *Open quantum generalisation of Hopfield neural networks*, J. Phys. A: Math. Theor. **51**(11), 115301 (2018), doi:10.1088/1751-8121/aaabcb.
- [735] K. B. Petersen and M. S. Pedersen, *The matrix cookbook*, [Mathematics - Waterloo University](#), Accessed: 2022-03-04 (2012).

图清单

0.1	科学中的机器学习蓬勃发展	2
0.2	人工智能、量子计算与物理学的相互作用	3
1.1	传统编程与基于数据驱动编程的机器学习	5
1.2	人工智能、机器学习与深度学习	6
1.3	本书内容	12
1.4	各章依赖关系树	13
2.1	损失函数示例	16
2.2	作为超参数的学习率	17
2.3	欠拟合与过拟合	20
2.4	偏差-方差权衡	22
2.5	二维问题中支持向量机的几何构造	29
2.6	神经网络	32
2.7	卷积滤波器	33
2.8	自动编码器	34
2.9	循环神经网络	35
2.10	简单前馈神经网络上的反向传播	40
3.1	Ising 模型	43
3.2	Ising 规范理论	44
3.3	利用主成分分析进行相分类	47
3.4	利用监督学习进行相分类	50
3.5	利用自编码器进行无监督学习	51
3.6	利用混淆学习进行相分类	53
3.7	利用基于预测的方法进行相分类	54
3.8	二维 Ising 模型自动编码器的解释	57
3.9	通过瓶颈解释神经网络	58
3.10	关联器网络	59
3.11	基于 Hessian 的可解释性	61
4.1	输入空间与特征空间中的二维玩具数据集	67
4.2	使用不同核的支持向量机分类	75
4.3	线性支持向量机应用于非线性可分数据集	76
4.4	贝叶斯神经网络	78
4.5	贝叶斯优化	83
4.6	采集函数示例	85
4.7	最优核构造算法	87
4.8	贝叶斯优化与高斯过程成功处理的三类主要量子问题	88
4.9	用于反馈回路的高斯过程与贝叶斯优化	89
4.10	作为量子计算势能面的高斯过程	90
4.11	用高斯过程外推未见过的量子相	91
5.1	受限 Boltzmann 机示意图	100
5.2	自回归神经网络量子态	102
5.3	作为神经网络量子态的循环神经网络架构	103
5.4	神经网络量子态的表达能力	104
5.5	各种 Ansatz 的示意图	105
5.6	神经网络量子态的临界淬火动力学	110
5.7	受限 Boltzmann 机 Ansatz 的基态结果	111
5.8	神经网络量子态的电子结构计算	113
5.9	神经网络量子态与量子近似优化算法	115
5.10	神经网络量子态与开放量子系统	117
5.11	循环神经网络量子层析	119
6.1	强化学习的基本设定	124
6.2	强化学习算法中的短期与长期奖励	125
6.3	不同投影模拟智能体的情节与组合记忆示意图	142
6.4	游走者与强化学习	145
6.5	AlphaGo 与 AlphaGo Zero 的表现比较	147
6.6	光学腔量子反馈中的强化学习	148
6.7	用于电路优化的强化学习	149
6.8	用于量子纠错的强化学习	150
6.9	强化学习延长量子比特寿命	152
6.10	利用强化学习寻找最优松弛	154
7.1	机器学习影响物理学	156

7.2	标准编程与可微编程	158
7.3	计算图示例	160
7.4	用可微编程求解逆 Schrödinger 问题	164
7.5	归一化流示意图	170
7.6	归一化流对概率质量的输运	172
7.7	实验纳米薄片装置	175
7.8	纳米薄片自动化方案	176
7.9	人类对薄片判断的差异	176
7.10	量子点实验装置	178
7.11	量子点机器学习方案	179
7.12	超冷原子的机器学习可观测量提取	180
7.13	模拟与实验的 p 空间密度	180
7.14	单自旋系统的 Hamiltonian 学习示意图	182
7.15	较大系统的 Hamiltonian 学习	183
7.16	特定 Hamiltonian 从 4 个格点标度到 50 个格点的方案	184
7.17	计算机启发实验算法	184
8.1	物理学影响机器学习	187
8.2	理解机器学习理论的统计物理学工具箱	187
8.3	经典与现代区域中的泛化误差	188
8.4	感知机的容量	192
8.5	教师-学生范式中泛化误差随任务难度的变化	194
8.6	委员会机与随机特征模型的结构	195
8.7	委员会机的泛化误差与专门化	196
8.8	不匹配教师-学生模型的泛化误差与模型参数化程度	197
8.9	教师-学生方案中的数据结构	198
8.10	过参数化委员会机的学习动力学	199
8.11	量子电路图示例	202
8.12	量子机器学习	203
8.13	在真实量子计算机上实现著名的 Shor 算法	205
8.14	量子器件增强的量子支持向量机	206
8.15	量子电路的变分优化	208
8.16	变分量子电路	209

算法清单

1	小批量随机梯度下降 (SGD)	18
2	主成分分析 (PCA)	47
3	t 分布随机邻域嵌入 (t-SNE)	48
4	混淆学习	53
5	贝叶斯优化 (BO)	82
6	Metropolis–Hastings 算法	99
7	用神经网络量子态搜索基态	108
8	神经网络量子态的实时 ($\xi = i$) 或虚时 ($\xi = 1$) 演化算法	111
9	Q-learning	132
10	REINFORCE	136
11	演员–评论家	141

缩略语清单

AD	自动微分	MPS	矩阵乘积态
AE	自动编码器	MSE	均方误差
AI	人工智能	NEI	含噪期望改进
ANN	人工神经网络	NF	归一化流
AR	自回归	NIS	神经重要性采样
ARNN	自回归神经网络	NISQ	含噪中等规模量子
BIC	Bayesian 信息准则	NMCMC	神经 Markov 链 Monte Carlo
BO	Bayesian 优化	NN	神经网络
CPU	中央处理器	NQS	神经网络量子态
CE	交叉熵	ODE	常微分方程
CNN	卷积神经网络	PC	主成分
∂P	可微编程	PCA	主成分分析
DL	深度学习	PES	势能面
DNN	深度神经网络	PI	改进概率
DQN	深度 Q 网络	POVM	正算符值测度
ECM	情节与组合记忆	PPT	部分转置为正
EI	期望改进	PQC	参数化量子电路
GAMP	广义近似消息传递	PS	投影模拟
GAN	生成对抗网络	QAOA	量子近似优化算法
GNS	生成神经采样器	QD	量子点
GP	Gaussian 过程	QML	量子机器学习
GPR	Gaussian 过程回归	RBM	受限 Boltzmann 机
GPU	图形处理器	RKHS	再生核 Hilbert 空间
IGT	Ising 规范理论	RL	强化学习
KRR	核岭回归	RNN	循环神经网络
KL	Kullback–Leibler	RUE	重采样不确定性估计
L-BFGS	有限内存 Broyden–Fletcher–Goldfarb–Shanno 算法	SGD	随机梯度下降
LASSO	最小绝对收缩与选择算子	SE	状态演化
LE	局域系综	SVM	支持向量机
MAE	平均绝对误差	t-SNE	t 分布随机邻域嵌入
MAP	最大后验估计量	t-VMC	含时变分 Monte Carlo
MCMC	Markov 链 Monte Carlo	TD	时序差分
MDP	Markov 决策过程	TN	张量网络
ML	机器学习	TNS	张量网络态
MLE	最大似然估计	VAE	变分自动编码器
		VQE	变分量子本征求解器

主题索引 (原书页码)

A		瓶颈 (bottleneck)	原 41, 42, 原 59, 原 66
行动 (action)	原 138	C	
行动偏好 (action preference)	原 153	容量 (capacity)	原 26, 原 206, 原 220
激活函数 (activation function)	原 39	分类 (classification)	原 14, 原 192
主动学习 (active learning)	原 16, 原 73, 原 95	聚类 (clustering)	原 16, 原 54
演员-评论家 (actor-critic)	原 155	委员会机 (committee machine)	原 13,
智能体 (agent)	原 137, 138		原 213–215, 原 219
异常检测 (anomaly detection)	原 60, 61,	卷积神经网络 (convolutional neural network)	
	原 72		原 40, 原 192
Ansatz (ansatz)	原 107–109, 原 117, 118	可解释性 (interpretability)	原 68
计算可处理态 (computationally tractable		临界任务难度 (critical task difficulty)	原 207
states)	原 109	交叉验证 (cross-validation)	原 24
平均场 (mean-field)	原 108	D	
自动编码器 (autoencoder)	原 41, 42, 原 59,	数据增强 (data augmentation)	原 192
	原 67	深度 Q 网络 (deep Q-network)	原 148
可解释性 (interpretability)	原 67	密度估计 (density estimation)	原 181, 182
量子自动编码器 (quantum autoencoder)		非参数 (non parametric)	原 182
	原 231	参数化 (parametric)	原 182
自动化流程 (automation procedure)	原 194	可微编程 (differentiable programming)	原 172
自回归模型 (autoregressive models)	原 42,	微分 (differentiation)	原 24, 原 175
	原 115, 原 185	自动微分 (automatic differentiation)	
自回归神经网络 (autoregressive neural			原 105, 原 175, 176
network)	原 42, 原 114, 115	手工微分 (manual differentiation)	原 175
B		数值微分 (numerical differentiation)	
反向传播 (backpropagation)	原 11, 12, 原 24,		原 175
	原 40, 原 44, 原 178	符号微分 (symbolic differentiation)	
基线 (baseline)	原 151		原 175
批量优化 (batch optimization)	原 192	降维 (dimensionality reduction)	原 53
Bayes 误差 (Bayes error)	原 31, 原 212	折扣因子 (discount factor)	原 140
Bayes 信息准则 (Bayesian information		E	
criterion)	原 97, 原 99	环境 (environment)	原 137, 138
Bayes 优化 (Bayesian optimization)	原 93,	环境动力学 (environment dynamics)	
	原 98, 99		原 141
采集函数 (acquisition function)	原 94, 95	轮次 (epoch)	原 23
Bayes 后验 (Bayesian posterior)	原 212	经验回放 (experience replay)	原 148
Bellman 方程 (Bellman equations)	原 144	利用 (exploitation)	原 141
Bellman 最优性方程 (optimal Bellman		探索 (exploration)	原 141
equations)	原 145		
偏差-方差权衡 (bias-variance trade-off)			
	原 27, 原 97, 原 206		

F

特征 (feature) 原 14–16, 原 32, 33, 原 76
 特征空间 (feature space) 原 76

G

高斯过程 (Gaussian process) 原 88, 原 93,
 原 98, 99
 泛化 (generalization) 原 25
 泛化误差 (generalization error) 原 25,
 原 27
 广义近似消息传递 (generalized approximate
 message passing) 原 212
 生成模型 (generative models) 原 15, 16,
 原 41, 原 115, 原 181
 深度生成模型 (deep generative models)
 原 181
 生成式神经采样器 (generative neural
 samplers) 原 184
 梯度下降 (gradient descent) 原 22
 随机梯度下降 (stochastic gradient
 descent) 原 24
 图形处理器 (graphics processing unit) 原 12,
 原 173, 原 235, 236

H

Hamiltonian 学习 (Hamiltonian learning)
 原 199
 Hessian 矩阵 (Hessian) 原 24, 原 71, 原 174
 超参数 (hyperparameter) 原 23

I

影响函数 (influence functions) 原 71
 可解释性 (interpretability) 原 64–68, 原 70,
 原 73, 原 158, 原 203

K

k-局域算符 (k-local operator) 原 110
 核 (kernel) 原 76
 核岭回归 (kernel ridge regression) 原 83
 核搜索 (kernel search) 原 98, 原 104
 核技巧 (kernel trick) 原 76, 原 78, 原 83
 Kullback–Leibler 散度 (Kullback–Leibler
 divergence) 原 31, 原 132, 原 171,
 原 183

L

混淆学习 (learning by confusion) 原 61
 学习率 (learning rate) 原 23
 线性回归 (linear regression) 原 33, 原 91
 逻辑回归 (logistic regression) 原 36
 损失函数 (loss function) 原 21, 原 97
 损失景观 (loss landscape) 原 24, 原 71, 72

M

Markov 链 Monte Carlo (Markov chain
 Monte Carlo) 原 111, 原 114
 Markov 决策过程 (Markov decision process)
 原 138, 原 141
 行动空间 (action space) 原 138, 原 141
 状态空间 (state space) 原 138, 原 141
 轨迹 (trajectory) 原 142
 Markov 性 (Markov property) 原 141
 最大似然 (maximum likelihood) 原 97, 原 183
 均方误差 (mean squared error) 原 28
 最小任务难度 (minimal task difficulty) 原 210
 模式坍塌 (mode collapse) 原 190
 模式坍塌 (连字符写法) (mode-collapse)
 原 189

N

神经网络 (neural network) 原 38
 神经网络量子态 (neural quantum states)
 原 112
 没有免费午餐定理 (no free lunch theorem)
 原 27
 含噪中等规模量子时代 (noisy
 intermediate-scale quantum era)
 原 224
 归一化流 (normalizing flow) 原 186

O

独热编码 (one hot encoding) 原 58
 在线学习 (online learning) 原 219
 过拟合 (overfitting) 原 26, 原 34, 原 97
 过参数化 (overparametrization) 原 215

P

感知机 (perceptron) 原 39, 原 206, 原 219
 感知机容量 (perceptron capacity) 原 207

量子感知机 (quantum perceptron)	原 220	无模型强化学习 (model-free reinforcement learning)	原 142
困惑度 (perplexity)	原 56	可靠性 (reliability)	原 65
相分类 (phase classification)	原 50, 原 103	局部集成 (local ensembles)	原 72
监督相分类 (supervised phase classification)	原 58	重采样不确定性估计 (resampling uncertainty estimation)	原 72
无监督相分类 (unsupervised phase classification)	原 53	欠规范化 (underspecification)	原 72
策略 (policy)	原 138, 原 142	副本技巧 (replica trick)	原 209
ϵ -greedy policy	原 141	表示空间 (representation space)	原 53
最优策略 (optimal policy)	原 138	表示定理 (representer theorem)	原 81, 原 92
策略梯度 (policy gradient)	原 149	再生核 Hilbert 空间 (reproducing kernel Hilbert space)	原 82
策略梯度定理 (policy gradient theorem)	原 149, 150	受限 Boltzmann 机 (restricted Boltzmann machine)	原 113
REINFORCE (REINFORCE)	原 150	回报 (return)	原 140
基于预测的方法 (prediction-based method)	原 62	折扣回报 (discounted return)	原 140, 原 142
主成分分析 (principal component analysis)	原 54	奖励 (reward)	原 138, 139

Q

Q-learning (Q-learning)	原 146
深度 Q-learning (deep Q-learning)	原 148
Double Q-learning (double Q-learning)	原 147
量子机器学习 (quantum machine learning)	原 221
量子多体问题 (quantum many-body problem)	原 107, 原 126
量子态层析 (quantum state tomography)	原 131
量子层析 (quantum tomography)	原 182
影子层析 (shadow tomography)	原 134

R

随机特征模型 (random feature model)	原 213, 214
循环神经网络 (recurrent neural network)	原 42, 原 115, 原 185
回归 (regression)	原 14, 原 27, 原 200
正则化 (regularization)	原 26, 原 66
强化学习 (reinforcement learning)	原 16, 原 137
基于模型的强化学习 (model-based reinforcement learning)	原 142

S

得分函数 (score function)	原 150
自平均 (self-averaging)	原 208
半监督学习 (semi-supervised learning)	原 16
孪生神经网络 (Siamese neural network)	原 68, 原 70
softmax (softmax)	原 36
状态 (强化学习, state (RL))	原 138
随机邻域嵌入 (SNE) (stochastic neighbor embedding (SNE))	原 56
t-分布 SNE (t-distributed SNE)	原 56
监督学习 (supervised learning)	原 16, 原 199
支持向量机 (support vector machine)	原 36
核支持向量机 (kernel support vector machine)	原 85
量子支持向量机 (quantum support vector machine)	原 223
支持向量机 (support vector machines)	
可解释性 (interpretability)	原 66

T

目标网络 (target network)	原 148, 149
教师-学生范式 (teacher-student paradigm)	原 206, 原 211, 原 220

时序差分学习 (temporal-difference learning) 原 146
 时序差分误差 (temporal-difference error) 原 146
 张量网络 (tensor networks) 原 109
 矩阵乘积态 (matrix product states) 原 109
 投影纠缠对态 (projected entangled pair states) 原 117
 迁移学习 (transfer learning) 原 102

U

不确定性 (uncertainty) 原 72, 原 94, 原 99
 欠拟合 (underfitting) 原 26
 无监督学习 (unsupervised learning) 原 16,
 原 53, 54, 原 56

V

价值函数 (value function) 原 143
 行动价值函数 (action-value function) 原 144
 优势 (advantage) 原 144
 状态价值函数 (state-value function) 原 144
 变分推断 (variational inference) 原 183
 变分量子本征求解器 (variational quantum eigensolver) 原 228
 变分态 (variational state) 原 107–113,
 原 120, 原 128, 原 135

术语索引

中文术语	英文术语	页码
人工智能	artificial intelligence, AI	2
机器学习	machine learning, ML	2
深度学习	deep learning, DL	4
阈值逻辑	threshold logic	5
控制论	cybernetics	5
赫布学习	Hebbian learning	6
Rosenblatt 感知机	Rosenblatt perceptron	6
反向传播	backpropagation	6
联结主义	connectionism	6
学习任务	learning task	8
回归	regression	9
分类	classification	9
密度估计	density estimation	9
生成问题	generative problem	9
数据	data	10
特征	feature	10
表示学习	representation learning	10
监督学习	supervised learning	10
无监督学习	unsupervised learning	10
强化学习	reinforcement learning, RL	11
主动学习	active learning	11
半监督学习	semi-supervised learning	11
假设类	hypothesis class	15
损失函数	loss function	15
均方误差	mean squared error, MSE	15
交叉熵	cross entropy, CE	15
平均绝对误差	mean absolute error, MAE	16
独热编码	one-hot encoding	16

中文术语	英文术语	页码
梯度下降	gradient descent	16
学习率	learning rate	17
轮次	epoch	17
超参数	hyperparameter	17
验证数据集	validation data set	17
交叉验证	cross-validation	17
自动微分	automatic differentiation, AD	17
损失景观	loss landscape	18
随机梯度下降	stochastic gradient descent, SGD	18
Hessian 矩阵	Hessian	18
反向模式	reverse mode	18
动量项	momentum term	19
自适应学习率	adaptive learning rate	19
贝叶斯优化	Bayesian optimization, BO	19
泛化	generalization	19
泛化误差	generalization error	19
测试集	test set	19
信息泄漏	information leakage	19
泛化差距	generalization gap	19
容量	capacity	19
过拟合	overfitting	20
欠拟合	underfitting	20
正则化	regularization	20
没有免费午餐定理	no free lunch theorem	20
偏差-方差权衡	bias-variance trade-off	20
信念	belief	23
随机变量	random variable	23
独立同分布	independent and identically distributed, i.i.d.	23
概率分布	probability distribution	23

中文术语	英文术语	页码
概率质量函数	probability mass function	23
概率密度函数	probability density function	23
联合概率分布	joint probability distribution	23
独立	independent	23
随机向量	random vector	23
条件概率	conditional probability	23
链式法则	chain rule	23
乘积法则	product rule	23
Bayes 规则	Bayes' rule	23
求和法则	sum rule	23
先验	prior	23
似然	likelihood	24
后验	posterior	24
Bayes 分类器	Bayes classifier	24
Bayes 误差	Bayes error	24
似然函数	likelihood function	24
相对熵	relative entropy	24
Kullback–Leibler 散度	Kullback–Leibler divergence, KL divergence	24
标准机器学习	standard machine learning	25
黑箱函数	black-box function	25
主成分分析	principal component analysis, PCA	25
高斯过程	Gaussian processes, GPs	25
核方法	kernel methods	25
线性模型	linear model	26
偏置	bias	26
最小二乘估计量	least-squares estimator, LSE	26
Moore–Penrose 逆	Moore–Penrose inverse	26
最大似然估计	maximum likelihood estimation, MLE	27
最大后验估计	maximum a posteriori estimate, MAP	27

中文术语	英文术语	页码
正则化强度	regularization strength	28
Tikhonov 正则化	Tikhonov regularization	28
岭回归	ridge regression	28
LASSO 回归	least absolute shrinkage and selection operator regression	28
逻辑回归	logistic regression	28
逻辑 sigmoid 函数	logistic sigmoid function	28
softmax 函数	softmax function	28
决策边界	decision boundary	29
支持向量机	support vector machine, SVM	29
支持点	support points	29
Lagrange 函数	Lagrange function	30
Lagrange 乘子	Lagrange multipliers	30
二次规划	quadratic program	30
序列最小优化	sequential minimal optimization	30
一对一方法	one-to-one approach	31
一对其余分类	one-to-rest classification	31
人工神经网络	artificial neural network, ANN	31
神经网络	neural network, NN	31
人工神经元	artificial neuron	31
感知机	perceptron	31
激活值	activation	31
激活函数	activation function	31
修正线性单元	rectified linear unit, ReLU	31
输入层	input layer	31
输出层	output layer	31
隐藏层	hidden layer	31
全连接	fully connected	31
架构	architecture	31
深度神经网络	deep neural network, DNN	31

中文术语	英文术语	页码
仿射映射	affine map	31
通用函数逼近器	universal function approximator	32
通用逼近定理	universal approximation theorem	32
前向传播	forward propagation	32
卷积神经网络	convolutional neural network, CNN	32
滤波器	filter	33
核	kernel	33
池化操作	pooling operation	33
自动编码器	autoencoder, AE	33
编码	encoding	33
潜变量	latent variable	33
瓶颈	bottleneck	33
解码	decoding	33
重构损失	reconstruction loss	33
信息瓶颈	information bottleneck	34
变分自动编码器	variational autoencoder, VAE	34
变分推断	variational inference	34
自回归神经网络	autoregressive neural network, ARNN	34
自回归模型	autoregressive model	34
循环神经网络	recurrent neural network, RNN	35
长短期记忆	long short-term memory, LSTM	35
门控循环单元	gated recurrent unit, GRU	35
Jacobian 矩阵	Jacobian matrix	37
Hadamard 积	Hadamard product	38
序参量	order parameter	42
磁化强度	magnetization	42
相分类	phase classification	42
对称性破缺相变	symmetry-breaking phase transition	42
Ising 规范理论	Ising gauge theory, IGT	42
铁磁 Ising 模型	ferromagnetic Ising model	42

中文术语	英文术语	页码
Boltzmann 分布	Boltzmann distribution	43
配分函数	partition function	43
元格	plaquette	45
降维	dimensionality reduction	45
表示空间	representation space	45
聚类	clustering	45
维数灾难	curse of dimensionality	46
主成分	principal component, PC	46
经验协方差矩阵	empirical covariance matrix	46
解释方差比	explained variance ratio	46
t 分布随机邻域嵌入	t-distributed stochastic neighbor embedding, t-SNE	48
统一流形逼近与投影	uniform manifold approximation and projection, UMAP	48
随机邻域嵌入	stochastic neighbor embedding, SNE	48
困惑度	perplexity	49
受挫系统	frustrated system	50
潜空间	latent space	51
相分离区域	phase-separated region	52
混淆学习	learning by confusion	52
基于预测的方法	prediction-based method	53
调控参数	tuning parameter	53
系统无关	system-agnostic	54
保真度易感率	fidelity susceptibility	55
可靠性	reliability	55
可解释性	interpretability	55
量子相变	quantum phase transition	55
符号回归	symbolic regression	56
问题神经元	question neuron	57
感受野	receptive field	58
解释网络	Interpretation Net	58

中文术语	英文术语	页码
关联探测神经网络	Correlation-Probing neural network	58
训练损失景观	training loss landscape	61
影响函数	influence function	61
重采样不确定性估计	resampling uncertainty estimation, RUE	61
局部集成	local ensemble, LE	61
留一训练	leave-one-out training	61
不确定性	uncertainty	62
自助法	bootstrapping	62
欠规范性	underspecification	62
未充分确定的	underdetermined	62
分布外点	out-of-distribution point	62
类条件概率	class-conditional probability	63
核	kernel	65
核技巧	kernel trick	65
输入空间	input space	65
特征空间	feature space	65
特征映射	feature map	66
内积	inner product	67
Hilbert 空间	Hilbert space	67
平方可积函数	square-integrable function	67
求值	evaluation	68
再生核	reproducing kernel	68
再生核 Hilbert 空间	reproducing kernel Hilbert space, RKHS	68
核函数	kernel function	68
表示定理	representer theorem	70
核岭回归	kernel ridge regression, KRR	72
核矩阵	kernel matrix	73
支持向量回归	support vector regression	73
松弛变量	slack variable	74
铰链损失	hinge loss	77

中文术语	英文术语	页码
贝叶斯神经网络	Bayesian neural network	77
克里金法	kriging	80
边际似然	marginal likelihood	81
采集函数	acquisition function	82
置信上界	Upper Confidence Bound, UCB	84
利用	exploitation	84
探索	exploration	84
批量优化	batch optimization	84
期望改进	Expected Improvement, EI	84
含噪期望改进	Noisy Expected Improvement, NEI	84
改进概率	Probability of Improvement, PI	84
模型选择	model selection	84
贝叶斯因子	Bayes factor	85
贝叶斯信息准则	Bayesian information criterion, BIC	86
渐近相合性	asymptotic consistency	86
朴素	naive	86
Akaike 信息准则	Akaike information criterion	86
逆问题	inverse problem	88
最优控制	optimal control	88
散射实验	scattering experiment	89
势能面	potential energy surface, PES	89
从头算	ab initio	89
迁移学习	transfer learning	90
外推	extrapolation	91
含噪中等规模量子	noisy intermediate-scale quantum, NISQ	92
变分量子本征求解器	variational quantum eigensolver, VQE	92
量子核	quantum kernel	93
量子多体问题	quantum many-body problem	94
变分方法	variational method	94
Ansatz	ansatz	94

中文术语	英文术语	页码
变分态	variational state	94
平均场态	mean-field state	95
张量网络态	tensor network state, TNS	96
矩阵乘积态	matrix product state, MPS	96
键维数	bond dimension	96
密度矩阵重整化群	density matrix renormalization group, DMRG	96
计算可处理态	computationally tractable state	96
k -局域算符	k -local operator	96
局域估计量	local estimator	97
Markov 链 Monte Carlo	Markov chain Monte Carlo, MCMC	98
细致平衡	detailed balance	98
Metropolis–Hastings 算法	Metropolis–Hastings algorithm	98
Jastrow 波函数	Jastrow wave function	99
神经网络量子态	neural quantum state, NQS	99
受限 Boltzmann 机	restricted Boltzmann machine, RBM	100
基于能量的模型	energy-based model	101
Hopfield 网络	Hopfield network	101
纠缠熵	entanglement entropy	103
体积律标度	volume-law scaling	103
面积律标度	area-law scaling	103
晶格对称性	lattice symmetry	106
随机重构	stochastic reconfiguration	106
变分原理	variational principle	107
向量–Jacobian 乘积	vector–Jacobian product	107
含时变分 Monte Carlo	time-dependent variational Monte Carlo, t-VMC	108
非保真度	infidelity	109
量子几何张量	quantum geometric tensor	109
Wick 旋转	Wick rotation	110

中文术语	英文术语	页码
虚时演化	imaginary-time evolution	110
常微分方程	ordinary differential equation, ODE	111
费米子	fermion	111
反对易关系	anticommutation relation	111
反对称性	antisymmetry	111
符号问题	sign problem	111
一次量子化	first quantization	111
Slater 行列式	Slater determinant	111
二次量子化	second quantization	112
Jordan–Wigner 变换	Jordan–Wigner transformation	112
Bravyi–Kitaev 编码	Bravyi–Kitaev encoding	112
辅助体系	ancillary system	112
电子结构	electronic structure	112
Pauli 串	Pauli string	113
自旋轨道	spin-orbital	113
量子电路	quantum circuit	114
量子门	quantum gate	114
么正算符	unitary operator	114
通用门集	universal gate set	114
保真度	fidelity	114
量子近似优化算法	quantum approximate optimization algorithm, QAOA	115
组合优化	combinatorial optimization	115
Transformer	transformer	115
自注意力	self-attention	115
Greenberger–Horne–Zeilinger 态	Greenberger–Horne–Zeilinger state	115
线性图态	linear graph state	115
开放量子系统	open quantum system	116
环境	environment	116
退相干	decoherence	116

中文术语	英文术语	页码
Born–Markov 近似	Born–Markov approximation	116
Lindblad 主方程	Lindblad master equation	116
密度算符	density operator	116
跳跃算符	jump operator	116
Liouvillian	Liouvillian	116
稳态	steady state	116
密度矩阵	density matrix	116
Hermitian	Hermitian	116
半正定	positive semidefinite	116
纯化	purification	116
正算符值测度	positive operator-valued measure, POVM	116
耗散相变	dissipative phase transition	117
量子态层析	quantum state tomography	118
“影子层析”	shadow tomography	120
样本复杂度	sample complexity	121
单轴扭转	one-axis twisting	121
量子码	quantum code	121
智能体	agent	122
行动	action	123
状态	state	123
奖励	reward	123
最优策略	optimal policy	123
策略	policy	123
状态空间	state space	123
行动空间	action space	123
自我博弈	self-play	123
延迟奖励	delayed rewards	124
折扣因子	discount factor	124
折扣回报	discounted return	125
回报	return	125

中文术语	英文术语	页码
ε -贪心策略	ε -greedy policy	126
Markov 决策过程	Markov decision process, MDP	126
Markov 性	Markov property	126
充分统计量	sufficient statistic	126
动力学	dynamics	126
状态转移概率	state-transition probability	126
轨迹	trajectory	127
无模型强化学习	model-free reinforcement learning	127
基于模型的强化学习	model-based reinforcement learning	127
环境模型	model of the environment	127
搜索树	search tree	128
价值函数	value function	128
状态价值函数	state-value function	129
行动价值函数	action-value function	129
优势	advantage	129
Bellman 方程	Bellman equations	129
偏序	partial ordering	129
Bellman 最优性方程	Bellman optimality equations	130
基于价值的强化学习	value-based reinforcement learning	130
回合	episode	131
时序差分学习	temporal-difference learning, TD learning	131
自举	bootstrapping	131
时序差分误差	temporal-difference error, TD error	131
SARSA	SARSA	131
期望 SARSA	expected SARSA	131
Q-learning	Q-learning	131
样本更新	sample update	131
离策略	off-policy	131
同策略	on-policy	131
最大化偏差	maximization bias	132

中文术语	英文术语	页码
正偏估计量	positively biased estimator	132
Double Q-learning	double Q-learning	133
深度 Q-learning	deep Q-learning	133
深度 Q 网络	deep Q-network, DQN	133
经验回放	experience replay	133
目标网络	target network	133
策略梯度	policy gradient	134
梯度上升	gradient ascent	134
策略梯度定理	policy gradient theorem	134
得分函数	score function	135
基线	baseline	136
白化	whiten	138
行动偏好	action preference	138
持续任务	continuing task	139
演员-评论家	actor-critic	140
演员	actor	140
评论家	critic	140
优势演员-评论家	advantage actor-critic, A2C	141
异步优势演员-评论家	asynchronous advantage actor-critic, A3C	141
自然梯度	natural gradient	141
信赖域	trust region	141
近端策略优化	proximal policy optimization	141
投影模拟	projective simulation, PS	141
情节与组合记忆	episodic and compositional memory, ECM	141
片段	clip	141
加权随机游走	weighted random walk	142
边辉光	edge glow	142
表格型方法	tabular method	143
Monte Carlo 树搜索	Monte Carlo tree search	146
可恢复量子信息	recoverable quantum information	151

中文术语	英文术语	页码
稳定子操作	stabilizer operation	151
错误症状	syndrome	151
表面码	surface code	151
裁判解码器	referee decoder	152
行动组合	action composition	153
松弛方法	relaxation method	153
正偏转置	positive partial transpose, PPT	154
半定规划	semidefinite programming	154
自主科学发现	autonomous scientific discovery	155
数据效率	data efficiency	155
可微编程	differentiable programming	156
程序空间	program space	156
图形处理器	graphics processing unit, GPU	157
张量处理器	tensor processing unit, TPU	157
专用硬件	application-specific hardware	157
神经形态计算	neuromorphic computing	157
科学机器学习	scientific machine learning	157
手工微分	manual differentiation	159
数值微分	numerical differentiation	159
符号微分	symbolic differentiation	159
截断误差	truncation error	159
浮点算术	floating-point arithmetic	159
舍入误差	round-off error	159
求值轨迹	evaluation trace	160
机器精度	machine precision	160
前向模式 AD	forward-mode automatic differentiation	160
计算图	computation graph	160
导数轨迹	derivative trace	160
双数	dual number	161
反向模式 AD	reverse-mode automatic differentiation	161

中文术语	英文术语	页码
伴随量	adjoint	161
算子重载	operator overloading	161
静态计算图	static computation graph	162
基于图的语言	graph-based language	162
最优 Jacobian 累积问题	optimal Jacobian accumulation problem	162
NP-完全	NP-complete	162
动态计算图	dynamic computation graph	163
基于追踪的 AD	tracing-based automatic differentiation	163
源到源 AD	source-to-source automatic differentiation	163
高层伴随规则	high-level adjoint rule	163
增广常微分方程	augmented ordinary differential equation	163
逆向设计问题	inverse-design problem	163
量子最优控制	quantum optimal control	164
截断	cutoff	164
随机动力学	stochastic dynamics	165
混沌系统	chaotic system	165
与语言无关	language-agnostic	165
可逆编程	reversible programming	165
深度生成模型	deep generative model	165
参数密度估计	parametric density estimation	166
非参数密度估计	non-parametric density estimation	166
反向 Kullback–Leibler 散度	reverse Kullback–Leibler divergence	167
正向 Kullback–Leibler 散度	forward Kullback–Leibler divergence	167
对抗训练	adversarial training	167
生成神经采样器	generative neural sampler, GNS	167
生成对抗网络	generative adversarial network, GAN	167
扩散模型	diffusion model	167
可处理密度	tractable density	168
神经重要性采样	neural importance sampling, NIS	168

中文术语	英文术语	页码
神经 Markov 链 Monte Carlo	neural Markov chain Monte Carlo, NMCMC	168
对抗目标	adversarial objective	168
生成器	generator	168
判别器	discriminator	168
闭式似然	closed-form likelihood	169
祖先采样	ancestral sampling	169
平凡化映射	trivializing map	169
输运映射	transport map	170
仿射耦合变换	affine coupling transformation	170
微分同胚	diffeomorphism	170
自采样	self-sampling	171
模式坍塌	mode collapse	172
提议移动	proposal move	172
遍历性区域	ergodicity regime	172
试探分布	trial distribution	172
归纳偏置	inductive bias	173
等变性	equivariance	173
自适应训练方法	adaptive training method	173
路径梯度	path-gradient	173
退火重要性采样	annealed importance sampling	173
实验自动化	experimental automation	174
飞行时间图像	time-of-flight image	174
数据增强	data augmentation	175
假阳性	false positive	175
假阴性	false negative	175
量子点	quantum dot	177
量子点接触	quantum point contact	177
电荷稳定性图	charge-stability diagram	177
单次拍摄图像	single-shot image	180

中文术语	英文术语	页码
量子噪声	quantum noise	181
Hamiltonian 学习	Hamiltonian learning	181
自主实验室	self-driving laboratory	185
氮空位中心	nitrogen-vacancy center	185
教师-学生范式	teacher-student paradigm	188
一般位置	general position	188
临界任务难度	critical task difficulty	189
无序系统	disordered system	189
自旋玻璃	spin glass	190
自平均性	self-averaging	190
Bayesian 后验	Bayesian posterior	193
Bayes 最优	Bayes optimal	193
广义近似消息传递	generalized approximate message passing (GAMP)	193
状态演化	state evolution (SE)	194
困难相	hard phase	194
委员会机	committee machine	194
软委员会机	soft committee machine	194
随机特征模型	random feature model	194
重叠矩阵	overlap matrix	195
专门化相变	specialization phase transition	195
显著与弱特征模型	salient and weak feature model	198
显著子空间	salient subspace	198
弱子空间	weak subspace	198
在线学习	online learning	199
动力学平均场理论	dynamical mean-field theory	200
多遍随机梯度下降	multi-pass stochastic gradient descent	200
量子机器学习	quantum machine learning (QML)	200
量子感知机	quantum perceptron	201
全量子优势	fully quantum advantage	201

中文术语	英文术语	页码
混合量子-经典算法	hybrid quantum-classical algorithm	201
基于门的量子计算	gate-based quantum computation	201
量子增强机器学习	quantum-enhanced machine learning	201
量子比特	qubit	202
受控非门	controlled NOT gate	202
经典数据	classical data	203
量子数据	quantum data	203
真实标签	ground-truth label	203
无梯度优化器	gradient-free optimizer	203
Bloch 球	Bloch sphere	203
计算复杂性理论	computational complexity theory	203
有界误差概率多项式时间	bounded-error probabilistic polynomial time (BPP)	203
有界误差量子多项式时间	bounded-error quantum polynomial time (BQP)	204
量子 Fourier 变换	quantum Fourier transform (QFT)	204
Shor 算法	Shor algorithm	204
量子相位估计算法	quantum phase estimation algorithm	204
Harrow-Hassidim-Lloyd 算法	Harrow-Hassidim-Lloyd algorithm (HHL)	204
门误差	gate error	205
退相干误差	decoherence error	205
读出误差	read-out error	205
容错量子计算	fault-tolerant quantum computation	205
量子纠错	quantum error correction	205
量子误差缓解	quantum error mitigation	205
压缩态	squeezed state	206
Frobenius 内积	Frobenius inner product	206
计算-反计算技巧	compute-uncompute trick	207
变分量子算法	variational quantum algorithm	207
参数化量子电路	parametrized quantum circuit	207

中文术语	英文术语	页码
目标函数	objective function	207
问题启发 Ansatz	problem-inspired ansatz	208
硬件高效 Ansatz	hardware-efficient ansatz	208
比特串	bit string	209
参数移位规则	parameter shift rule	209
数据重上传	data reuploading	210
量子卷积神经网络	quantum convolutional neural network	210
对称性保护拓扑相	symmetry-protected topological phase	210
循环量子神经网络	recurrent quantum neural network	210
量子强化学习	quantum reinforcement learning	210
量子自动编码器	quantum autoencoder	210
垃圾量子比特	trash qubit	211
量子 Born 机	quantum Born machine	211
量子电路 Born 机	quantum circuit Born machine	211
相干热态	coherent thermal state	211
基于稳定子方法	stabilizer-based approach	211
主动缓解技术	active mitigation technique	211
贫瘠高原问题	barren-plateau problem	211
Haar 分布	Haar distribution	212
电路编译	circuit compilation	212
Solovay–Kitaev 定理	Solovay–Kitaev theorem	212
CQ 范式	CQ paradigm	212
激子–极化激元	exciton–polariton	216
白化	whitening	220