

---

---

# 深度学习的数学理论

*Mathematical Theory of Deep Learning*

---

PHILIPP PETERSEN · JAKOB ZECH

arXiv:2407.18384v4 · arXiv · 2026

Model: Codex GPT-5

审核: 曹溪能

Updated: 3 Sep 2026

## 译本说明

本译本以 arXiv:2407.18384v4 的公开 PDF 为可见内容与结构的最高依据，并以同版本源代码辅助恢复公式、标签、引文键和图件。若两者不一致，以 PDF 为准；疑似原文错误记录于项目的 ‘ISSUES.md’，不作静默更正。

译本保持原书的定义、定理、证明、公式、图表、引用与编号关系。中文数学术语在全书范围内统一，首次正式引入的核心概念同时保留英文原词。本文件采用 MathTranslations 个性化模板排版，但不包含其 logo 或网站标识。

审核：曹溪能

3 Sep 2026

# 目录

|                              |           |
|------------------------------|-----------|
| 译本说明                         | i         |
| 前言                           | vii       |
| 记号                           | viii      |
| <b>第 1 章 导论</b>              | <b>2</b>  |
| 1.1 深度学习的数学                  | 2         |
| 1.2 深度学习概览                   | 2         |
| 1.3 它为何有效?                   | 5         |
| 1.4 内容提要与写作理念                | 6         |
| 1.5 本书未涵盖的内容                 | 8         |
| 参考文献与延伸阅读                    | 9         |
| <b>第 2 章 前馈神经网络</b>          | <b>10</b> |
| 2.1 形式定义                     | 10        |
| 2.1.1 神经网络的基本运算              | 12        |
| 2.2 规模的概念                    | 12        |
| 2.3 激活函数                     | 13        |
| 参考文献与延伸阅读                    | 15        |
| <b>第 3 章 万能逼近</b>            | <b>16</b> |
| 3.1 一个万能逼近定理                 | 16        |
| 3.1.1 万能逼近族                  | 16        |
| 3.1.2 浅层神经网络                 | 17        |
| 3.1.3 深度神经网络                 | 22        |
| 3.1.4 其他范数                   | 24        |
| 3.2 超表达激活函数与 Kolmogorov 叠加定理 | 24        |
| <b>第 4 章 样条</b>              | <b>30</b> |
| 4.1 B 样条与光滑函数                | 30        |
| 4.2 用高阶 S 形激活函数重新逼近 B 样条     | 31        |
| <b>第 5 章 ReLU 神经网络</b>       | <b>37</b> |
| 5.1 ReLU 基本演算                | 37        |
| 5.1.1 恒等映射                   | 37        |
| 5.1.2 复合                     | 38        |
| 5.1.3 并行化                    | 39        |
| 5.1.4 线性组合                   | 40        |
| 5.2 连续分段线性函数                 | 41        |
| 5.3 单纯形片                     | 46        |
| 5.3.1 $\Omega$ 的三角剖分         | 46        |
| 5.3.2 正则三角剖分的规模界             | 47        |

|               |                      |            |
|---------------|----------------------|------------|
| 5.3.3         | 局部凸三角剖分的规模界          | 50         |
| 5.4           | Hölder 连续函数的收敛率      | 52         |
|               | 文献与延伸阅读              | 54         |
| <b>第 6 章</b>  | <b>ReLU 神经网络的仿射片</b> | <b>56</b>  |
| 6.1           | 上界                   | 56         |
| 6.2           | 上界的紧性                | 58         |
| 6.3           | 实践中的片数               | 59         |
|               | 文献与延伸阅读              | 64         |
|               | 习题                   | 65         |
| <b>第 7 章</b>  | <b>深层 ReLU 神经网络</b>  | <b>66</b>  |
| 7.1           | 平方函数                 | 66         |
| 7.2           | 乘法                   | 68         |
| 7.3           | 多项式、解析函数与深度分离        | 70         |
| 7.4           | $C^{k,s}$ 函数         | 72         |
|               | 文献与延伸阅读              | 77         |
|               | 习题                   | 79         |
| <b>第 8 章</b>  | <b>高维逼近</b>          | <b>80</b>  |
| 8.1           | 维数灾难                 | 80         |
| 8.1.1         | 数据需求                 | 81         |
| 8.1.2         | 参数数量                 | 83         |
| 8.1.3         | 无穷次可微函数              | 86         |
| 8.2           | Barron 类             | 88         |
| 8.3           | 具有复合结构的函数            | 92         |
| 8.4           | 流形上的函数               | 95         |
|               | 文献与延伸阅读              | 98         |
|               | 习题                   | 99         |
| <b>第 9 章</b>  | <b>插值</b>            | <b>100</b> |
| 9.1           | 万能插值                 | 100        |
| 9.2           | 最优插值与重建              | 101        |
| 9.2.1         | 动机                   | 102        |
| 9.2.2         | Lipschitz 连续函数的最优重建  | 102        |
| 9.2.3         | 最优 ReLU 重建           | 105        |
|               | 文献与延伸阅读              | 106        |
|               | 习题                   | 107        |
| <b>第 10 章</b> | <b>神经网络训练</b>        | <b>109</b> |
| 10.1          | 梯度下降法                | 109        |
| 10.1.1        | 结构条件与极小化子的存在性        | 110        |
| 10.1.2        | 梯度下降法的收敛性            | 113        |
| 10.2          | 随机梯度下降法              | 114        |



|               |                        |            |
|---------------|------------------------|------------|
| 10.2.1        | 动机与衰减学习率               | 115        |
| 10.2.2        | 随机梯度下降法的收敛性            | 117        |
| 10.3          | 加速                     | 119        |
| 10.3.1        | 重球法                    | 119        |
| 10.3.2        | Nesterov 加速            | 121        |
| 10.4          | 自适应学习率与逐坐标学习率          | 124        |
| 10.4.1        | 逐坐标缩放                  | 124        |
| 10.4.2        | 算法                     | 125        |
| 10.5          | 反向传播                   | 127        |
| 10.5.1        | 基本思想                   | 128        |
| 10.5.2        | 前馈神经网络                 | 129        |
|               | 文献与延伸阅读                | 132        |
|               | 习题                     | 133        |
| <b>第 11 章</b> | <b>宽神经网络与神经切线核</b>     | <b>135</b> |
| 11.1          | 线性最小二乘回归               | 135        |
| 11.1.1        | 极小化子的存在性               | 136        |
| 11.1.2        | 梯度下降法                  | 138        |
| 11.2          | 特征方法与核最小二乘回归           | 139        |
| 11.2.1        | 极小化子的存在性               | 140        |
| 11.2.2        | 核技巧                    | 140        |
| 11.2.3        | 梯度下降法                  | 142        |
| 11.3          | 切线核                    | 143        |
| 11.4          | 全局极小化子                 | 144        |
| 11.5          | 与训练后线性化模型的接近性          | 148        |
| 11.5.1        | 模型预测的演化                | 148        |
| 11.5.2        | 极限模型预测                 | 150        |
| 11.6          | 浅层神经网络的训练动力学           | 152        |
| 11.6.1        | 架构                     | 152        |
| 11.6.2        | 神经切线核                  | 153        |
| 11.6.3        | 训练动力学与模型预测             | 155        |
| 11.6.4        | 与 Gaussian 过程和核最小二乘的联系 | 160        |
| 11.6.5        | 初始化的作用                 | 164        |
|               | 文献与延伸阅读                | 164        |
|               | 习题                     | 166        |
| <b>第 12 章</b> | <b>损失景观分析</b>          | <b>167</b> |
| 12.1          | 损失景观的可视化               | 168        |
| 12.2          | 伪谷                     | 169        |
| 12.3          | 鞍点                     | 171        |
|               | 文献与延伸阅读                | 173        |
|               | 习题                     | 175        |

|                           |            |
|---------------------------|------------|
| <b>第 13 章 神经网络空间的形状</b>   | <b>176</b> |
| 13.1 Lipschitz 参数化        | 176        |
| 13.2 神经网络空间的凸性            | 179        |
| 13.3 闭性与最佳逼近性质            | 182        |
| 13.3.1 连续选取               | 183        |
| 13.3.2 最佳逼近的存在性           | 185        |
| 13.3.3 权重爆炸现象             | 185        |
| 文献与延伸阅读                   | 186        |
| 习题                        | 187        |
| <b>第 14 章 深度神经网络的泛化性质</b> | <b>188</b> |
| 14.1 学习设定                 | 188        |
| 14.2 经验风险最小化              | 190        |
| 14.3 泛化界                  | 191        |
| 14.4 由覆盖数导出的泛化界           | 192        |
| 14.5 深度神经网络的覆盖数           | 194        |
| 14.6 逼近-复杂度权衡             | 197        |
| 14.7 最优权衡下的风险界            | 199        |
| 14.8 由 VC 维得到 PAC 学习      | 200        |
| 14.8.1 定义与例子              | 200        |
| 14.8.2 基于 VC 维的泛化         | 202        |
| 14.9 可达到逼近率的下界            | 203        |
| 文献与延伸阅读                   | 206        |
| 习题                        | 207        |
| <b>第 15 章 过参数化机制下的泛化</b>  | <b>208</b> |
| 15.1 双下降现象                | 208        |
| 15.1.1 重新审视最小二乘回归         | 209        |
| 15.1.2 一个例子               | 210        |
| 15.2 权重大小                 | 212        |
| 15.3 理论依据                 | 213        |
| 文献与延伸阅读                   | 215        |
| 习题                        | 216        |
| <b>第 16 章 鲁棒性与对抗样本</b>    | <b>217</b> |
| 16.1 对抗样本                 | 217        |
| 16.2 Bayes 分类器            | 218        |
| 16.3 仿射分类器                | 219        |
| 16.4 ReLU 神经网络            | 223        |
| 16.5 鲁棒性                  | 224        |
| 16.5.1 全局 Lipschitz 正则性   | 224        |
| 16.5.2 局部正则性              | 225        |

|                                     |            |
|-------------------------------------|------------|
| 文献与延伸阅读 . . . . .                   | 228        |
| 习题 . . . . .                        | 229        |
| <b>第 17 章 现代架构</b>                  | <b>230</b> |
| 17.1 残差神经网络 . . . . .               | 230        |
| 17.1.1 反向传播与梯度消失 . . . . .          | 231        |
| 17.1.2 万能性 . . . . .                | 233        |
| 17.1.3 何时应使用残差网络? . . . . .         | 237        |
| 17.2 卷积神经网络 . . . . .               | 237        |
| 17.2.1 何时应使用卷积神经网络? . . . . .       | 244        |
| 17.3 Transformer . . . . .          | 244        |
| 17.3.1 嵌入与位置编码 . . . . .            | 245        |
| 17.3.2 因果自注意力机制 . . . . .           | 245        |
| 17.3.3 Transformer 块 . . . . .      | 248        |
| 17.3.4 用 Transformer 生成文本 . . . . . | 250        |
| 17.3.5 何时应使用 Transformer? . . . . . | 251        |
| 习题 . . . . .                        | 253        |
| <b>附录 A 概率论</b>                     | <b>254</b> |
| A.1 Sigma-代数、拓扑与测度 . . . . .        | 254        |
| A.2 随机变量 . . . . .                  | 255        |
| A.2.1 函数的可测性 . . . . .              | 255        |
| A.2.2 分布与期望 . . . . .               | 256        |
| A.3 条件分布、边缘分布与独立性 . . . . .         | 257        |
| A.3.1 联合分布与边缘分布 . . . . .           | 258        |
| A.3.2 独立性 . . . . .                 | 258        |
| A.3.3 条件分布 . . . . .                | 259        |
| A.4 集中不等式 . . . . .                 | 260        |
| <b>附录 B 线性代数与泛函分析</b>               | <b>263</b> |
| B.1 奇异值分解与伪逆 . . . . .              | 263        |
| B.2 向量空间 . . . . .                  | 264        |
| B.2.1 度量空间 . . . . .                | 265        |
| B.2.2 赋范空间 . . . . .                | 265        |
| B.2.3 Banach 空间 . . . . .           | 266        |
| B.2.4 Hilbert 空间 . . . . .          | 267        |
| <b>参考文献</b>                         | <b>270</b> |
| <b>术语索引</b>                         | <b>297</b> |

## 前言

本书介绍深度学习数学分析中的若干核心思想，旨在帮助学生和研究人员迅速熟悉这一领域，并为开设深度学习数学理论的大学课程奠定基础。我们撰写本书的主要目标，是给出一系列严谨而易于理解的结果，帮助读者认识深度学习中的基本数学概念。为此，我们优先追求简洁，而非一般性。

作为一部深度学习数学导论，本书并不试图穷尽这个仍在迅速发展的领域，因而未涵盖若干重要研究方向。特别地，我们更侧重数学结果而非实证研究，尽管准确阐述深度学习理论需要二者兼备。

本书面向数学及相关领域的学生 and 研究人员。我们相信，每一位勤勉的研究人员或学生都能够研读本书；不过，为获得最佳阅读体验，读者最好熟悉分析、线性代数、概率论以及泛函分析基础。为帮助读者，附录回顾了概率论和泛函分析中的若干关键概念。

全书围绕深度学习理论的三大支柱组织：逼近论 (approximation theory)、优化理论 (optimization theory) 与统计学习理论 (statistical learning theory)。这一结构对应于深度学习模型理论分析中通常出现的三个误差项，并受到采用同一纲要的近期著作 [243, 308, 148] 的启发。更具体地说，第 1 章给出概览，并提出理解深度学习所需回答的核心问题。第 2 章至第 9 章讨论逼近论结果，第 10 章至第 13 章讨论深度学习的优化理论，第 14 章至第 16 章处理深度学习的统计问题。最后一章，即第 17 章，讨论前述各章计算架构中与实际应用相关的多种改型。

本书源自作者讲授的一系列课程。P.P. 曾在维也纳大学讲授题为“神经网络理论”的课程，J.Z. 曾在海德堡大学讲授题为“深度学习理论”的课程；这些课程的讲义构成了本书的基础。许多同事和学生通过富有启发性的讨论与宝贵建议为本书作出了贡献，我们对此深表感谢。我们特别感谢以下各位：Jonathan Garcia Rebellon、Jakob Lanser、Andrés Felipe Lerma Pineda、Marvin Koß、Martin Mauser、Davide Modesto、Martina Neuman、Bruno Perreux、Johannes Asmus Petersen、Milutin Popovic、Tuan Quach、Tim Rakowski、Lorenz Riess、Jakob Fabian Rohner、Jonas Schuhmann、Peter Školník、Matej Vedak、Simon Weissmann、Josephine Westermann 以及 Ashia Wilson。

# 记号

| 符号                               | 说明                                                            | 参见              |
|----------------------------------|---------------------------------------------------------------|-----------------|
| $\mathcal{A}$                    | 各层宽度组成的向量                                                     | 定义 12.1         |
| $\mathfrak{A}$                   | 一个 $\sigma$ -代数                                               | 定义 A.1          |
| $\text{aff}(S)$                  | $S$ 的仿射包                                                      | (5.3.7)         |
| $\mathfrak{B}_d$                 | $\mathbb{R}^d$ 上的 Borel $\sigma$ -代数                          | 第 A.1 节         |
| $\mathcal{B}^n$                  | $n$ 阶 B-样条                                                    | 定义 4.2          |
| $B_r(x)$                         | 度量空间 $X$ 中以 $x$ 为中心、半径 $r \geq 0$ 的球                          | (B.2.1)         |
| $B_r^d$                          | $\mathbb{R}^d$ 中以 $\mathbf{0}$ 为中心、半径 $r \geq 0$ 的球           |                 |
| $B_1^{k,d}$                      | $C^k([0,1]^d)$ 中以 $0$ 为中心的单位球                                 | (8.1.1)         |
| $C^{0,s}(\Omega)$                | 从 $\Omega$ 到 $\mathbb{R}$ 的 $s$ -Hölder 连续函数                  | 定义 5.22         |
| $C^k(\Omega)$                    | 从 $\Omega$ 到 $\mathbb{R}$ 的 $k$ 次连续可微函数                       | 定义 3.2          |
| $C^{k,s}(\Omega)$                | 满足 $f^{(k)} \in C^{0,s}(\Omega)$ 的 $C^k(\Omega)$ 函数 $f$       | 定义 7.9          |
| $C_c^\infty(\Omega)$             | 从 $\Omega$ 到 $\mathbb{R}$ 、支集紧含于 $\Omega$ 的无穷次可微函数            |                 |
| $f_n \xrightarrow{\text{cc}} f$  | $f_n$ 紧收敛于 $f$                                                | 定义 3.1          |
| $\text{co}(S)$                   | 集合 $S$ 的凸包                                                    | (5.3.1)         |
| $f * g$                          | $f$ 与 $g$ 的卷积                                                 | (3.4)           |
| $\mathcal{D}$                    | 数据分布                                                          | (1.4), 第 14.1 节 |
| $D^\alpha f$                     | $f$ 关于多重指标 $\alpha$ 的偏导数                                      |                 |
| $\text{depth}(\Phi)$             | $\Phi$ 的深度                                                    | 定义 2.1          |
| $\varepsilon_{\text{approx}}$    | 逼近误差                                                          | (14.2.2)        |
| $\varepsilon_{\text{gen}}$       | 泛化误差                                                          | (14.2.2)        |
| $\varepsilon_{\text{int}}$       | 插值误差                                                          | (14.2.3)        |
| $\mathbb{E}[X]$                  | 随机变量 $X$ 的期望                                                  | (A.2.1)         |
| $\mathbb{E}[X   Y]$              | 给定 $Y$ 时随机变量 $X$ 的条件期望                                        | 第 A.3.3 小节      |
| $\mathcal{G}(S, \varepsilon, X)$ | 集合 $S \subseteq X$ 的 $\varepsilon$ -覆盖数                       | 定义 14.10        |
| $\gamma_{k,d,N}$                 | 连续非线性 $N$ -宽度                                                 | (8.1.4)         |
| $\Gamma_C$                       | 常数为 $C$ 的 Barron 空间                                           | 第 8.2 节         |
| $\nabla_x f$                     | $f$ 关于 $x$ 的梯度; 有限维时等于 $(\frac{\partial f}{\partial x})^\top$ |                 |
| $\oslash$                        | 逐分量 (Hadamard) 除法                                             |                 |
| $\otimes$                        | 逐分量 (Hadamard) 乘积                                             |                 |
| $h_S$                            | 样本 $S$ 的经验风险最小化器                                              | 定义 14.5         |
| $\mathbf{I}_d$                   | $d \times d$ 单位矩阵                                             |                 |
| $\Phi_L^{\text{id}}$             | 恒等 ReLU 神经网络                                                  | 引理 5.1          |

续下页

| 符号                                              | 说明                                                                                     | 参见        |
|-------------------------------------------------|----------------------------------------------------------------------------------------|-----------|
| $\mathbb{1}_S$                                  | 集合 $S$ 的示性函数                                                                           |           |
| $\langle \cdot, \cdot \rangle$                  | $\mathbb{R}^d$ 上的 Euclidean 内积                                                         |           |
| $\langle \cdot, \cdot \rangle_H$                | 向量空间 $H$ 上的内积                                                                          | 定义 B.11   |
| $k_{\mathcal{T}}$                               | 三角剖分中共享同一节点的单元最大数目                                                                     | (5.3.2)   |
| $\hat{K}_n(\mathbf{x}, \mathbf{x}')$            | 经验切线核                                                                                  | (11.3.5)  |
| $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$ | 损失景观定义函数                                                                               | 定义 12.2   |
| $\text{Lip}(f)$                                 | 函数 $f$ 的 Lipschitz 常数                                                                  | (9.2.1)   |
| $\text{Lip}_M(\Omega)$                          | $\Omega$ 上的 $M$ -Lipschitz 连续函数                                                        | (9.2.4)   |
| $\mathcal{L}$                                   | 一般损失函数                                                                                 | 第 14.1 节  |
| $\mathcal{L}_{0-1}$                             | 0-1 损失                                                                                 | 第 14.1 节  |
| $\mathcal{L}_{\text{ce}}$                       | 二元交叉熵损失                                                                                | 第 14.1 节  |
| $\mathcal{L}_2$                                 | 平方损失                                                                                   | 第 14.1 节  |
| $\ell^p(\mathbb{N})$                            | 以 $\mathbb{N}$ 为指标集的 $p$ -可和序列空间                                                       | 第 B.2.3 节 |
| $L^p(\Omega)$                                   | $\Omega$ 上的 Lebesgue 空间                                                                | 第 B.2.3 节 |
| $\mathcal{M}$                                   | 分段连续且局部有界的函数                                                                           | 定义 3.1    |
| $\mathcal{N}_d^m(\sigma; L, n)$                 | 输入维数为 $d$ 、输出维数为 $m$ 、激活函数为 $\sigma$ 、深度为 $L$ 、宽度为 $n$ 的多层感知机集合                        | 定义 3.7    |
| $\mathcal{N}_d^m(\sigma; L)$                    | 对所有 $n \in \mathbb{N}$ 的 $\mathcal{N}_d^m(\sigma; L, n)$ 之并                            | 定义 3.7    |
| $\mathcal{N}(\sigma; \mathcal{A}, B)$           | 架构为 $\mathcal{A}$ 、激活函数为 $\sigma$ 且所有权重的模不超过 $B$ 的神经网络集合                               | 定义 12.1   |
| $\mathcal{N}^{\text{sp}}(\sigma; L, B, s)$      | 深度至多为 $L$ 、非零权重至多有 $s$ 个且所有权重的模不超过 $B$ 的神经网络集合                                         | 定义 14.14  |
| $\mathcal{N}^{\text{sp},*}(\sigma; L, B, s)$    | $\mathcal{N}^{\text{sp}}(\sigma; B, s)$ 中值域包含于 $[-1, 1]$ 的神经网络                         | (14.5.2)  |
| $\mathbb{N}$                                    | 正自然数集                                                                                  |           |
| $\mathbb{N}_0$                                  | 包含零的自然数集                                                                               |           |
| $N(\mathbf{m}, \mathbf{C})$                     | 均值 $\mathbf{m} \in \mathbb{R}^d$ 、协方差 $\mathbf{C} \in \mathbb{R}^{d \times d}$ 的多元正态分布 |           |
| $n_{\mathcal{A}}$                               | 层宽由 $\mathcal{A}$ 描述的神经网络的参数数目                                                         | 定义 12.1   |
| $\ \cdot\ $                                     | $\mathbb{R}^d$ 中向量的 Euclidean 范数或 $\mathbb{R}^{n \times d}$ 中矩阵的谱范数                    |           |
| $\ \cdot\ _F$                                   | 矩阵的 Frobenius 范数                                                                       |           |
| $\ \cdot\ _{\infty}$                            | $\mathbb{R}^d$ 上的无穷范数或函数的上确界范数                                                         | (8.1.2)   |
| $\ \cdot\ _p$                                   | $\mathbb{R}^d$ 上的 $p$ -范数                                                              |           |
| $\ \cdot\ _X$                                   | 向量空间 $X$ 上的范数                                                                          |           |
| $\mathbf{0}$                                    | 零向量或零矩阵                                                                                |           |
| $O(\cdot)$                                      | Landau 记号                                                                              |           |

续下页

| 符号                                              | 说明                                                                                                                                                                    | 参见             |
|-------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------|
| $\omega(\eta)$                                  | 节点 $\eta$ 的星形邻域                                                                                                                                                       | (5.3.5)        |
| $\Omega_\Lambda(c)$                             | 损失景观的次水平集                                                                                                                                                             | 定义 12.3        |
| $\mathbf{1}$                                    | 常数 1 向量                                                                                                                                                               |                |
| $\partial f(\mathbf{x})$                        | $f$ 在 $\mathbf{x}$ 处的次梯度集合                                                                                                                                            | 定义 10.19       |
| $\frac{\partial f}{\partial \mathbf{x}}$        | 偏导数; 若 $f: \mathbb{R}^d \rightarrow \mathbb{R}^k$ , 则 $\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \in \mathbb{R}^{k \times d}$ ; 张量值 $f$ 与 $\mathbf{x}$ 的情形类似 |                |
| $\mathcal{P}_n(\mathbb{R}^d)$ 或 $\mathcal{P}_n$ | $\mathbb{R}^d$ 上次数为 $n$ 的多元多项式空间                                                                                                                                      | 例 3.6          |
| $\mathcal{P}(\mathbb{R}^d)$ 或 $\mathcal{P}$     | $\mathbb{R}^d$ 上任意次数的多元多项式空间                                                                                                                                          | 例 3.6          |
| $\mathbb{P}_X$                                  | 随机变量 $X$ 的分布                                                                                                                                                          | 定义 A.10        |
| $\mathbb{P}[A]$                                 | 事件 $A$ 的概率                                                                                                                                                            | 定义 A.5         |
| $\mathbb{P}[A   B]$                             | 给定 $B$ 时事件 $A$ 的条件概率                                                                                                                                                  | 定义 A.3.2       |
| $\mathcal{PN}(\mathcal{A}, B)$                  | 架构为 $\mathcal{A}$ 且所有权重的模不超过 $B$ 的神经网络参数集                                                                                                                             | 定义 12.1        |
| $\text{Pieces}(f, \Omega)$                      | $f$ 在 $\Omega$ 上的片数                                                                                                                                                   | 定义 6.1         |
| $\Phi(\mathbf{x})$                              | 以输入 $\mathbf{x}$ 表示的模型 (如神经网络; 省略参数依赖)                                                                                                                                |                |
| $\Phi(\mathbf{x}, \mathbf{w})$                  | 以输入 $\mathbf{x}$ 和参数 $\mathbf{w}$ 表示的模型 (如神经网络)                                                                                                                       |                |
| $\Phi^{\text{lin}}$                             | 初始化点附近的线性化                                                                                                                                                            | (11.3.1)       |
| $\Phi_n^{\min}$                                 | 最小值神经网络                                                                                                                                                               | 引理 5.11        |
| $\Phi_\varepsilon^\times$                       | 乘法神经网络                                                                                                                                                                | 引理 7.3         |
| $\Phi_{n,\varepsilon}^\times$                   | $n$ 个数的乘法神经网络                                                                                                                                                         | 命题 7.4         |
| $\Phi_2 \circ \Phi_1$                           | 神经网络的复合                                                                                                                                                               | 引理 5.2         |
| $\Phi_2 \bullet \Phi_1$                         | 神经网络的稀疏复合                                                                                                                                                             | 引理 5.2         |
| $(\Phi_1, \dots, \Phi_m)$                       | 神经网络的并行化                                                                                                                                                              | (5.1.1)        |
| $\mathbf{A}^\dagger$                            | 矩阵 $\mathbf{A}$ 的伪逆                                                                                                                                                   |                |
| $\mathbb{Q}$                                    | 有理数集                                                                                                                                                                  |                |
| $\mathbb{R}$                                    | 实数集                                                                                                                                                                   |                |
| $\mathbb{R}_-$                                  | 非正实数集                                                                                                                                                                 |                |
| $\mathbb{R}_+$                                  | 非负实数集                                                                                                                                                                 |                |
| $R_\sigma$                                      | 实现映射                                                                                                                                                                  | 定义 12.1        |
| $R^*$                                           | Bayes 风险                                                                                                                                                              | (14.1.1)       |
| $\mathcal{R}(h)$                                | 假设 $h$ 的风险                                                                                                                                                            | 定义 14.2        |
| $\widehat{\mathcal{R}}_S(h)$                    | 假设 $h$ 关于样本 $S$ 的经验风险                                                                                                                                                 | (1.3), 定义 14.4 |
| $\mathcal{S}_n$                                 | 基数 B-样条                                                                                                                                                               | 定义 4.1         |
| $\mathcal{S}_{\ell,t,n}^d$                      | 多元基数 B-样条                                                                                                                                                             | 定义 4.2         |

续下页

| 符号                                         | 说明                                                       | 参见         |
|--------------------------------------------|----------------------------------------------------------|------------|
| $ S $                                      | 任意集合 $S$ 的基数, 或 $S \subseteq \mathbb{R}^d$ 的 Lebesgue 测度 |            |
| $\overset{\circ}{S}$                       | 集合 $S$ 的内部                                               |            |
| $\overline{S}$                             | 集合 $S$ 的闭包                                               |            |
| $\partial S$                               | 集合 $S$ 的边界                                               |            |
| $S^c$                                      | 集合 $S$ 的补集                                               |            |
| $S^\perp$                                  | 集合 $S$ 的正交补                                              | 定义 B.15    |
| $\sigma$                                   | 一般激活函数                                                   |            |
| $\sigma_a$                                 | 参数化 ReLU 激活函数                                            | 第 2.3 节    |
| $\sigma_{\text{ReLU}}$                     | ReLU 激活函数                                                | 第 2.3 节    |
| $\text{sign}$                              | 符号函数                                                     |            |
| $s_{\max}(\mathbf{A})$                     | 矩阵 $\mathbf{A}$ 的最大奇异值                                   |            |
| $s_{\min}(\mathbf{A})$                     | 矩阵 $\mathbf{A}$ 的最小正奇异值                                  |            |
| $\text{size}(\Phi)$                        | $\Phi$ 的自由网络参数数目                                         | 定义 2.4     |
| $\text{span}(S)$                           | $S$ 的线性包或张成空间                                            |            |
| $\mathcal{T}$                              | 三角剖分                                                     | 定义 5.13    |
| $\mathcal{V}$                              | 三角剖分中的节点集合                                               | 定义 5.13    |
| $\mathbb{V}[X]$                            | 随机变量 $X$ 的方差                                             | 第 A.2.2 节  |
| $\text{VCdim}(\mathcal{H})$                | 函数集合 $\mathcal{H}$ 的 VC 维                                | 定义 14.21   |
| $\mathcal{W}$                              | 权重初始化的分布                                                 | 第 11.6.1 节 |
| $\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}$ | 神经网络第 $\ell$ 层的权重与偏置                                     | 定义 2.1     |
| $\text{width}(\Phi)$                       | $\Phi$ 的宽度                                               | 定义 2.1     |
| $\mathbf{x}^{(\ell)}$                      | 神经网络第 $\ell$ 层的输出                                        | 定义 2.1     |
| $\bar{\mathbf{x}}^{(\ell)}$                | 预激活值                                                     | (10.5.6)   |
| $X'$                                       | 赋范空间 $X$ 的对偶空间                                           | 定义 B.9     |



## 导论

## 1.1 深度学习的数学

2012 年，一种深度学习架构在 ImageNet 大规模视觉识别挑战赛 (ILSVRC) 中取得了前所未有的成绩，由此革新了计算机视觉领域 [167]。这种名为 AlexNet 的深度学习架构显著超越了所有竞争方法。数年后 2016 年 3 月，基于深度学习的 AlphaGo 在五番棋比赛中战胜了当时最强的围棋棋手李世石 [289]。围棋的可能着法极其繁多，是人工智能面临的高度复杂问题。正因如此，许多研究人员曾认为，战胜顶尖人类围棋棋手还要再等几十年。

这些突破以及众多其他进展，引起了（几乎）所有学科科学家的兴趣。突出例子包括 DeepMind 的 AlphaFold [152]——它在 2020 年革新了蛋白质结构预测，并使其开发者获得 2024 年诺贝尔化学奖——以及 GPT-3（及后续版本）等大语言模型前所未有的语言能力 [316, 49]，还有 Stable Diffusion、Midjourney、DALL-E 和 Gemini 2.5 Flash Image（更广为人知的名称是 Nano Banana）等生成式人工智能模型的兴起。同样，尽管神经网络的数学研究历史悠久，这些开创性进展仍重新唤起了数学家对深度学习理论基础的兴趣。然而，数学界起初有一个明确共识：我们并不理解这项技术为何如此有效！事实上，至少从表面上看，许多数学理由都应当阻碍我们观察到的成功。

过去十年间，这一领域逐渐成熟。尽管仍有许多开放问题，数学家对深度学习已有更深入的理解。近年来，人们对这些模型的内部机制提出了多种新的解释和见解。在后续各章详细讨论之前，我们先从高层次介绍深度学习，重点考察用于函数逼近的监督学习框架；这是本书的中心主题。

## 1.2 深度学习概览

深度学习是指应用由梯度方法训练的深度神经网络 (deep neural network)，以识别未知的输入—输出关系。这种方法包含三个关键要素：深度神经网络、基于梯度的训练以及预测。下面分别说明这三个要素。

深度神经网络由神经元组合而成。一个神经元 (neuron) 是如下形式的函数：

$$\mathbb{R}^d \ni \mathbf{x} \mapsto \nu(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b), \quad (1.1)$$

其中  $\mathbf{w} \in \mathbb{R}^d$  是权重向量 (weight vector)， $b \in \mathbb{R}$  称为偏置 (bias)，函数  $\sigma$  称为激活函数 (activation function)。这一概念源于 McCulloch 和 Pitts [196]，是生物神经元的一种数学模型。若取  $\sigma$  为 Heaviside 函数，即  $\sigma = \mathbf{1}_{\mathbb{R}_+}$ ，其中  $\mathbb{R}_+ := [0, \infty)$ ，那么当输入  $\mathbf{x}$  的加权和超过阈值  $-b$  时，神经元就会“激活”。图 1.1 给出了神经元示意图。注意，固定  $d$  和  $\sigma$  后，神经元集合可由  $d+1$  个实数  $w_1, \dots, w_d, b \in \mathbb{R}$  自然参数化。




图 1.1: 单个神经元  $\nu$  的示意图. 神经元接收六个输入  $(x_1, \dots, x_6) = \mathbf{x}$ , 计算其加权和  $\sum_{j=1}^6 x_j w_j$ , 加上偏置  $b$ , 最后应用激活函数  $\sigma$ , 得到输出  $\nu(x)$ .

神经网络是通过连接神经元而形成的函数, 其中一个神经元的输出成为另一个神经元的输入. 一种简单而又极为常见的神经网络是所谓的前馈神经网络 (feedforward neural network). 其特点是神经元分层排列, 第  $\ell + 1$  层神经元的输入只能来自第  $\ell$  层神经元.

我们先把浅层前馈神经网络 (shallow feedforward neural network) 定义为: 对一组具有相同输入和相同激活函数的神经元的输出施加一个仿射变换. 这里, 仿射变换 (affine transformation) 是映射  $T: \mathbb{R}^p \rightarrow \mathbb{R}^q$ , 满足对某个  $\mathbf{W} \in \mathbb{R}^{q \times p}$  和  $\mathbf{b} \in \mathbb{R}^q$  有  $T(\mathbf{x}) = \mathbf{W}\mathbf{x} + \mathbf{b}$ , 其中  $p, q \in \mathbb{N}$ .

因此, 形式上, 浅层前馈神经网络是如下形式的映射  $\Phi$ :

$$\mathbb{R}^d \ni \mathbf{x} \mapsto \Phi(\mathbf{x}) = T_1 \circ \sigma \circ T_0(\mathbf{x}),$$

其中  $T_0, T_1$  是仿射变换, 而  $\sigma$  理解为逐分量作用于  $T_1(\mathbf{x})$ . 图 1.2 给出了浅层神经网络的示意图.

深层前馈神经网络 (deep feedforward neural network) 由浅层神经网络复合而成, 得到如下类型的映射:

$$\mathbb{R}^d \ni \mathbf{x} \mapsto \Phi(\mathbf{x}) = T_{L+1} \circ \sigma \circ \dots \circ T_1 \circ \sigma \circ T_0(\mathbf{x}),$$

其中  $L \in \mathbb{N}$ , 且  $(T_j)_{j=0}^{L+1}$  均为仿射变换. 复合次数  $L$  称为深度神经网络的层数 (number of layers). 与单个神经元类似, (深度) 神经网络可视为一个参数化函数类, 其参数 (parameters) 就是决定仿射变换  $(T_j)_{j=0}^{L+1}$  的矩阵与向量的各个分量.

确定神经网络的结构或架构 (architecture) (例如激活函数和层数) 之后, 深度学习的第二步是为参数确定合适的取值. 实际中, 这通过最小化一个目标函数 (objective function) 来实现. 本书关注的监督学习 (supervised learning) 中, 该目标函数依赖于输入—输出对; 它们通常称为训练数据 (training data), 或简称样本 (sample).




图 1.2: 浅层神经网络示意图. 仿射变换  $T_0$  具有  $(x_1, \dots, x_6) = \mathbf{x} \mapsto \mathbf{W}\mathbf{x} + \mathbf{b}$  的形式, 其中  $\mathbf{W}$  的各行分别是三个神经元的权重向量  $\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3$ .

具体而言, 令  $S = (\mathbf{x}_i, \mathbf{y}_i)_{i=1}^m$  为一个样本, 其中  $\mathbf{x}_i \in \mathbb{R}^d$  是输入,  $\mathbf{y}_i \in \mathbb{R}^k$  是相应输出, 且  $d, k \in \mathbb{N}$ . 我们的目标是找到深度神经网络  $\Phi$ , 使得在某种有意义的意义下

$$\Phi(\mathbf{x}_i) \approx \mathbf{y}_i \quad \text{对所有 } i = 1, \dots, m \quad (1.2)$$

成立. 例如, 可以把 “ $\approx$ ” 理解为关于 Euclidean 范数相近; 更一般地, 也可以要求衡量两个输入之间差异的某个函数  $\mathcal{L}$  满足  $\mathcal{L}(\Phi(\mathbf{x}_i), \mathbf{y}_i)$  很小. 这样的函数  $\mathcal{L}$  称为损失函数 (loss function).

实现式 (1.2) 的一种标准方法, 是最小化  $\Phi$  关于样本  $S$  的所谓经验风险 (empirical risk):

$$\hat{\mathcal{R}}_S(\Phi) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\Phi(\mathbf{x}_i), \mathbf{y}_i). \quad (1.3)$$

这个量衡量了  $\Phi$  在训练点 (training points)  $\mathbf{x}_1, \dots, \mathbf{x}_m$  上预测  $\mathbf{y}_1, \dots, \mathbf{y}_m$  的效果.

若  $\mathcal{L}$  可微, 并且对所有  $\mathbf{x}_i$ , 输出  $\Phi(\mathbf{x}_i)$  关于神经网络参数可微, 则经验风险  $\hat{\mathcal{R}}_S(\Phi)$  关于这些参数的梯度定义良好. 这一梯度可用称为反向传播 (backpropagation) 的技术高效计算. 因而可以用 (随机) 梯度下降等优化算法最小化式 (1.3). 这些算法产生一系列神经网络参数以及相应的神经网络函数  $\Phi_1, \Phi_2, \dots$ , 期望其经验风险逐步下降. 图 1.3 展示了这种序列的一种可能行为.

深度学习的最后一部分涉及如下问题: 上述过程是否真的学到了某种规律. 假设优化程序已经收敛或被终止, 并得到神经网络  $\Phi_*$ . 优化过程虽旨在最小化训练样本  $S$  上的经验风险, 但我们最终关心的并不是  $\Phi_*$  在  $S$  上表现如何, 而是它在  $S$  之外的新数据点  $(\mathbf{x}_{\text{new}}, \mathbf{y}_{\text{new}})$  上的表现.

为了对此作出有意义的陈述, 我们假设输入—输出空间 (此处为  $\mathbb{R}^d \times \mathbb{R}^k$ ) 上存在一个数据分布 (data distribution)  $\mathcal{D}$ , 样本  $S$  的元素以及所有其他数据点都从该分布抽取. 换言之, 我们把  $S$  视为从  $\mathcal{D}$  独立同分布抽取的样本, 而  $(\mathbf{x}_{\text{new}}, \mathbf{y}_{\text{new}})$  也独立地从

$\mathcal{D}$  抽取. 若希望  $\Phi_*$  的平均表现良好, 就需要控制

$$\mathcal{R}(\Phi_*) = \mathbb{E}_{(\mathbf{x}_{\text{new}}, \mathbf{y}_{\text{new}}) \sim \mathcal{D}} [\mathcal{L}(\Phi_*(\mathbf{x}_{\text{new}}), \mathbf{y}_{\text{new}})], \quad (1.4)$$

它称为  $\Phi_*$  的风险 (risk). 若风险并不显著大于经验风险, 就说神经网络  $\Phi_*$  的泛化误差 (generalization error) 较小. 反之, 若风险远大于经验风险, 就说  $\Phi_*$  对训练数据发生了过拟合 (overfitting); 这意味着  $\Phi_*$  记住了训练样本, 却不能很好地泛化到训练集之外的数据.




图 1.3: 一系列一维神经网络  $\Phi_1, \dots, \Phi_4$ , 它们依次减小样本  $S = (\mathbf{x}_i, \mathbf{y}_i)_{i=1}^6$  的经验风险.

### 1.3 它为何有效?

我们自然会问: 上一节所述深度学习流程为何最终能够成功学习, 即取得较小风险? 给定样本  $(\mathbf{x}_i, \mathbf{y}_i)_{i=1}^m$ , 是否存在神经网络, 使得对所有  $i = 1, \dots, m$  都有  $\Phi(\mathbf{x}_i) \approx \mathbf{y}_i$ ? 优化程序能否产生有意义的结果? 仅知经验风险较小, 能否控制风险?

在某些假设下, 这些问题大多可以得到肯定回答; 然而, 这些假设在实际深度学习中往往并不成立. 下面考察一些可能的解释, 并会看到它们引出了更多问题.

神经网络研究中的一个基本结果是所谓的万能逼近定理 (universal approximation theorem), 将在第 3 章讨论. 它指出, 紧区域上的每个连续函数都能由浅层神经网络以任意精度 (在一致意义下) 逼近.

然而, 该结果没有回答实际中至关重要的效率问题. 例如, 为追求计算效率, 我们可能希望找出能够拟合数据的最小神经网络. 这自然引出问题: 架构对神经网络表达能力有何作用? 此外, 把经验风险最小化视为逼近问题时, 我们会遇到逼近论的核心挑战——维数灾难 (curse of dimensionality). 高维函数逼近之难众所周知, 而且难度随维数增长呈指数上升. 然而, 许多成功的深度学习架构恰恰工作在这种高维机制下. 为何这些神经网络看起来能够克服所谓的维数灾难?

如第 10 章将讨论的，有时可以证明梯度下降收敛到全局极小值，但这通常至少要求目标函数是凸的。然而，没有理由认为经验风险关于网络参数是凸函数。事实上，由于网络中反复复合非线性激活函数，经验风险通常高度非线性且非凸。因此，一般不能保证优化程序收敛到全局极小值；它可能困在局部（非全局）极小值或鞍点。那么，为何优化输出在实际中往往仍然有意义？

在第 14 章将回顾的传统统计学习理论中，可以先验地界定风险超过经验风险的程度；这种界通常表示为容许函数集合（神经网络类）的某种复杂度除以训练样本数。对固定架构的神经网络类而言，该复杂度大致就是神经网络参数的数目。实际中通常使用参数数目多于训练样本数的神经网络，这称为过参数化机制（overparameterized regime）。在这种机制下，上述经典估计失去意义。

尽管如此，为何深层过参数化架构仍能对未见数据作出准确预测？此外，尽管深层架构往往具有良好泛化能力，它们有时会在经过精心构造的特定样本上严重失效。在图像分类任务中，这些样本与正确分类图像的差异可能极其微小，人眼甚至无法察觉。这样的样本称为对抗样本（adversarial example）；它们的存在给深度学习应用带来巨大挑战。

## 1.4 内容提要与写作理念

本书讨论上一节提出的问题，给出数学上严谨且易于理解的答案。我们关注可证明的陈述，并在呈现时优先追求简洁清楚，而非一般性。有时我们只在特殊情形或较强假设下阐明核心思想；这样做既是为了避免过度技术化，也因为许多问题尚无定论。下面概述各章内容，并指出与上一节问题相关的部分。

**第 2 章：前馈神经网络。** 引入本书的主要研究对象——前馈神经网络。

**第 3 章：万能逼近。** 介绍神经网络函数逼近的经典观点，并给出两个万能逼近结果。这类陈述说明，只要网络规模足够大，神经网络就能以任意精度逼近给定函数类中的每个函数。第一个结果在对激活函数极宽泛的假设下成立，讨论紧区域上连续函数的一致逼近。第二个结果表明，对一种十分特殊的激活函数，网络规模可以与所需精度无关；这凸显出解释万能逼近结果时必须谨慎。

**第 4 章：样条。** 超越万能逼近，开始考察神经网络的逼近速率，特别研究逼近质量与网络参数数目之间的关系。对所谓 S 形激活函数，我们建立神经网络逼近与样条逼近之间的联系。这表明，更光滑的函数需要更少的网络参数；但要获得这种更高效率，就必须使用更深的神经网络。这一观察让我们初步看到深度在深度学习中的重要性。

**第 5 章：ReLU 神经网络。** 聚焦实际中最常用的激活函数之一 ReLU。我们证明 ReLU 网络类恰好等于连续分段线性函数的集合，从而为其表达能力提供理论基础。对给定连续分段线性函数，我们研究表示它所需的 ReLU 网络宽度和深度；最后利用分段线性函数的逼近论，导出逼近 Hölder 连续函数的收敛速率。



- 第 6 章：ReLU 神经网络的仿射片。** 在建立对 ReLU 神经网络的一些直觉后，讨论其潜在局限。我们通过计算网络生成的仿射区域数来分析 ReLU 神经网络。关键洞见是：深层神经网络生成的区域数可以比浅层网络多出指数倍，这为神经网络架构中深度的潜在优势提供了进一步证据。
- 第 7 章：深层 ReLU 神经网络。** 研究深层 ReLU 神经网络生成大量仿射区域的能力是否能转化为函数逼近上的实际优势。对光滑函数，我们确实证明了远优于浅层网络的逼近速率，进一步增进了我们对深度及其与神经网络架构表达能力之间联系的理解。
- 第 8 章：高维逼近。** 前几章建立的收敛速率在高维情形会显著恶化。本章考察三种能够严格证明神经网络克服维数灾难的情形。
- 第 9 章：插值。** 从逼近转向训练数据的精确插值。分析精确插值成立的条件及其对经验风险最小化的影响，并给出一个构造性证明，说明 ReLU 网络可以表示数据的一种最优插值函数。
- 第 10 章：神经网络训练。** 开始研究深度学习的训练过程。首先讨论（随机）梯度下降与凸优化基础，随后考察加速方法，并说明 Adam 等常用训练算法背后的关键原理；最后讨论如何用反向传播算法实现这些神经网络训练方法。
- 第 11 章：宽神经网络与神经切线核。** 引入神经切线核，作为分析神经网络训练行为的工具。先回顾利用数据逼近函数的线性回归和核回归，并讨论在目标函数中加入正则项的影响。随后证明，对某些宽度充分大的架构，梯度下降的训练动力学近似于核回归，并收敛到全局极小值。这解释了为何在某些条件下，尽管目标函数非凸，我们仍能训练神经网络而不会困在（不良）局部极小值。最后讨论神经网络与 Gaussian 过程之间的著名联系，说明过参数化网络在实际中为何未必过拟合。
- 第 12 章：损失景观分析。** 通过分析损失景观——即经验风险作为神经网络参数的函数——从另一角度看待优化问题。理论论证表明，过参数化程度提高会增强损失景观中谷地和盆地之间的连通性，使过参数化架构更容易到达所有极小值均为全局极小值的区域。此外，与非全局极小值相关的大多数驻点都是鞍点。这进一步解释了经验事实：深层架构的优化往往不会困在非全局极小值。
- 第 13 章：神经网络空间的形状。** 虽然第 11 章和第 12 章揭示了神经网络训练成功的潜在原因，本章却说明固定架构的神经网络集合从优化角度看具有一些不理想的性质。特别地，这个集合通常非凸；一般而言，它也不具有最佳逼近性质，即对给定函数，集合内未必存在实现最佳逼近的神经网络。
- 第 14 章：深度神经网络的泛化性质。** 为理解深度神经网络为何能成功泛化到训练集之外的未见数据点，我们研究经典统计学习理论，重点以神经网络函数作为假设类。随后说明如何为深度学习建立泛化界，从理论上理解其在未见数据上的表现。
- 第 15 章：过参数化机制下的泛化。** 当神经网络参数数目超过训练样本数时，上一章的泛化界不再有意义，但许多成功网络架构正工作在这一机制下。为深入理解这种

情形，我们描述双降现象并给出一种可能解释，从而回答深度神经网络为何尽管高度过参数化仍表现良好。

**第 16 章：鲁棒性与对抗样本。** 考察旨在欺骗神经网络的输入——对抗样本——为何存在，给出一些对抗样本产生原因的理论解释，并讨论可能的防范策略。

**第 17 章：现代架构。** 最后一章介绍实际中最成功的若干神经网络架构改型，包括所谓的残差连接、卷积神经网络以及 Transformer。

## 1.5 本书未涵盖的内容

本书研究深度学习的一些核心主题，但未涵盖的内容更多。下面列出若干省略的有趣问题及相关文献线索。

（深层）前馈神经网络远非神经网络的唯一类型。实际中必须根据数据类型调整架构。第 17 章将讨论三类高级架构：残差神经网络、卷积神经网络和 Transformer；但实际选择远不止这些。特别地，本书不讨论图神经网络 [48]，尽管它是图结构数据的自然选择。对序列输入，我们只讨论 Transformer，而略去长短期记忆 (LSTM) 网络 [133] 等成熟替代方案。

本书关注监督学习，其中每个数据点  $x_i$  都带有标签  $y_i$ ；然而机器学习还有广阔的无监督学习 (unsupervised learning) 领域，其中数据没有标签。经典无监督学习问题包括聚类和降维 [285, 第 22/23 章]。

深度学习中一个不使用标签的热门方向是物理信息神经网络 (physics-informed neural network) [255]。在这里，训练神经网络使其满足某个偏微分方程 (PDE)，损失函数则度量它偏离该方程的程度。

最后，强化学习 (reinforcement learning) 是一种让智能体与环境交互、并根据其动作获得反馈的技术。动作由需要学习的所谓策略引导 [202, 第 17 章]。在深度强化学习中，这一策略由深度神经网络建模。前述 AlphaGo 正是以强化学习为基础。

在稀缺资源分配（如医学中的器官移植、金融信贷审批和招聘决定）或工程任务（如桥梁结构优化、自动驾驶导航和预测性维护）等关键决策过程中使用深度神经网络，要求我们理解其决策过程。无论从实践还是伦理角度，这都至关重要。

实践上，理解模型如何得出决策有助于改进性能并缓解问题，使我们能够确认模型按预期运行而不产生不良结果。例如，在桥梁设计中，理解模型为何建议或拒绝某种构型，有助于工程师发现潜在薄弱环节，最终得到更安全、更高效的设计。伦理上，尤其当结果会对个人或社会产生重大影响时，决策透明度至关重要；数据或模型设计中的偏差可能导致歧视性结果，因此可说明性不可或缺。

然而，解释深度神经网络的预测并不容易。即使知道网络权重和偏置，线性变换与非线性激活函数反复而复杂的相互作用仍常使模型成为黑箱。关于各种可解释性技术（并不限于深度神经网络）的全面综述，见文献 [203]。关于公平性问题，例如可参见文献 [85, 15]。

本书虽然聚焦可证明的理论结果，但应用强力推动着深度学习领域；没有实践经验，就不可能全面理解深度学习。这方面已有许多讲解出色的资源。我们推荐文献 [102, 62, 249]，以及只需用 Google（或其他搜索工具）搜索即可找到的无数在线教程。

这一领域发展迅速，新的想法不断产生并接受检验。本书无法给出完整综述。不过，我们希望它能为读者打下坚实基础，使其掌握基本知识与原理，从而迅速把握并理解领域的新进展。

## 参考文献与延伸阅读

本书每章末尾都会简要概述相关工作和该章使用的参考文献。

在本导论中，我们特别指出另外几部近期的深度学习教材和著作。关于神经网络的历史综述，见文献 [273, 174]。关于神经网络和深度学习的一般性教材，可参见文献 [125, 110, 249]，其中包括较新的专著。更偏数学的导论例如见文献 [8, 148, 52]。关于神经网络的实现，例如可参见文献 [102, 62]。



# 前馈神经网络

前馈神经网络——下文简称神经网络 (NN) ——是本书的核心研究对象. 本章给出神经网络的形式定义, 讨论神经网络的规模, 并简要介绍常用的激活函数.

## 2.1 形式定义

我们已在式 (1.1) 和图 1.1 中定义了单个神经元  $\nu$ . 神经网络由多个神经元相互连接而成. 下面精确定义这种连接过程.

**定义 2.1:** 设  $L \in \mathbb{N}$ ,  $d_0, \dots, d_{L+1} \in \mathbb{N}$ , 且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 若存在矩阵  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$  和向量  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$ , 其中  $\ell = 0, \dots, L$ , 使得在定义

$$\mathbf{x}^{(0)} := \mathbf{x}, \quad (2.1a)$$

$$\mathbf{x}^{(\ell)} := \sigma(\mathbf{W}^{(\ell-1)}\mathbf{x}^{(\ell-1)} + \mathbf{b}^{(\ell-1)}), \quad \ell = 1, \dots, L, \quad (2.1b)$$

$$\mathbf{x}^{(L+1)} := \mathbf{W}^{(L)}\mathbf{x}^{(L)} + \mathbf{b}^{(L)} \quad (2.1c)$$

后, 对所有  $\mathbf{x} \in \mathbb{R}^{d_0}$  都有

$$\Phi(\mathbf{x}) = \mathbf{x}^{(L+1)},$$

则称函数  $\Phi: \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_{L+1}}$  为神经网络.

称  $L$  为深度 (depth), 称  $d_{\max} = \max_{\ell=1, \dots, L} d_\ell$  为宽度 (width), 称  $\sigma$  为激活函数, 并称  $(\sigma; d_0, \dots, d_{L+1})$  为神经网络  $\Phi$  的架构. 此外, 对  $\ell = 0, \dots, L$ ,  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$  称为  $\Phi$  的权重矩阵 (weight matrix),  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$  称为其偏置向量 (bias vector).

把所有权重和偏置收集到一个维数适当的向量中:

$$\mathbf{w} = ((\mathbf{W}^{(0)}, \mathbf{b}^{(0)}), \dots, (\mathbf{W}^{(L)}, \mathbf{b}^{(L)})). \quad (2.2)$$

若要强调对  $\mathbf{w}$  的依赖, 也写作

$$\Phi(\mathbf{x}, \mathbf{w}). \quad (2.3)$$

**注 2.2:** 通常, 不同的架构、权重和偏置选择可以给出同一个函数  $\Phi: \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_{L+1}}$ . 因而, 仅由  $\Phi$  所实现的函数, 不能赋予这些概念唯一的含义.

下文提到神经网络  $\Phi$  时, 既可能指它实现的函数, 也可能指定义 2.1 所定义的某个具体实现. 特别地, 在讨论深度或规模等性质时, 始终默认已经固定了一个满足相应性质的  $\Phi$  的构造.  $\diamond$

神经网络的架构通常画成连通图，如图 2.1 所示. 图中的节点 (node) 表示神经元 (的输出). 节点按层 (layer) 排列，定义 2.1 中的  $\mathbf{x}^{(\ell)}$  对应第  $\ell$  层的神经元. 式 (2.1a) 中的  $\mathbf{x}^{(0)}$  也称为输入层 (input layer)，式 (2.1c) 中的  $\mathbf{x}^{(L+1)}$  称为输出层 (output layer). 中间各层称为隐藏层 (hidden layer)，其输出由式 (2.1b) 给出. 隐藏层的数目就是深度. 为正确理解这类图，需要注意：按照定义 2.1 的约定，除最后一层外，每次仿射变换之后都要应用激活函数.

深度为一的神经网络称为浅层网络 (shallow network)，深度大于一的称为深层网络. 文献对“深度神经网络”一词的用法并不完全一致；有些作者仅在深度远大于一时才使用“深层”，而“远大于”的确切含义取决于具体应用.

本书始终只考虑定义 2.1 意义下的神经网络. 不过需要强调，这只是神经网络的一种类型，虽然简单，却极为常见. 这种构造有许多可能且广泛使用的变体，例如：

- 每层  $\ell$  可以使用不同的激活函数  $\sigma_\ell$ ，甚至每个节点都可以使用不同的激活函数.
- 残差神经网络 (residual neural network) 允许“跳跃连接” [128]. 也就是说，信息可以跨过若干层：第  $\ell$  层节点的输入可以是  $\mathbf{x}^{(0)}, \dots, \mathbf{x}^{(\ell-1)}$ ，而不只是  $\mathbf{x}^{(\ell-1)}$ ；参见式 (2.1).
- 与前馈神经网络不同，循环神经网络 (recurrent neural network) 允许信息向后流动，即第  $\ell$  层节点可以接收  $\mathbf{x}^{(\ell-1)}, \dots, \mathbf{x}^{(L+1)}$  作为输入，而不只是  $\mathbf{x}^{(\ell-1)}$ . 这会在信息流中形成环，因此必须引入时间指标  $t \in \mathbb{N}$ ，因为某个节点在时刻  $t$  与时刻  $t+1$  的输出可能不同.




图 2.1: 具有三个隐藏层的神经网络示意图，其中  $d_0 = 3$ 、 $d_1 = 4$ 、 $d_2 = 3$ 、 $d_3 = 4$ 、 $d_4 = 2$ . 该神经网络的深度为三，宽度为四.

下面说明神经网络语境中的其他几个常用术语：

- **参数**：神经网络的参数是权重矩阵和偏置向量的全部分量. 为方便记号，常把它们收集成式 (2.2) 中的单个向量  $\mathbf{w}$ . 参数可以调整，并在训练过程中学习；它们决定网络所实现的具体函数.
- **超参数** (hyperparameter)：超参数是定义网络架构 (及训练过程) 的设定，但 (通常) 不会在训练中直接学习. 例子包括深度、每层神经元数和激活函数的选择. 它们在训练开始前设定.

- **权重**：“权重”一词常作广义使用，指神经网络的全部参数，包括权重矩阵和偏置向量。
- **模型 (model)**：对固定架构，式 (2.2) 中网络参数  $\mathbf{w}$  的每种选择都定义一个具体函数  $\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w})$ 。在深度学习中，这个函数通常称为模型。更一般地，“模型”可指由一组参数  $\mathbf{w} \in \mathbb{R}^n$  ( $n \in \mathbb{N}$ ) 参数化的任意函数。

### 2.1.1 神经网络的基本运算

神经网络可以按多种方式相互组合。下一个命题讨论线性组合、复合和并行化。其形式证明是熟悉神经网络的良好练习，留作习题 2.5。

**命题 2.3**：设两个神经网络  $\Phi_1, \Phi_2$  的架构分别为

$$(\sigma; d_0^1, d_1^1, \dots, d_{L_1+1}^1) \quad \text{和} \quad (\sigma; d_0^2, d_1^2, \dots, d_{L_2+1}^2).$$

则有：

1. 对每个  $\alpha \in \mathbb{R}$ ，存在架构为  $(\sigma; d_0^1, d_1^1, \dots, d_{L_1+1}^1)$  的神经网络  $\Phi_\alpha$ ，使得

$$\Phi_\alpha(\mathbf{x}) = \alpha \Phi_1(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^{d_0^1}.$$

2. 若  $d_0^1 = d_0^2 =: d_0$  且  $L_1 = L_2 =: L$ ，则存在架构为  $(\sigma; d_0, d_1^1 + d_1^2, \dots, d_{L+1}^1 + d_{L+1}^2)$  的神经网络  $\Phi_{\text{parallel}}$ ，使得

$$\Phi_{\text{parallel}}(\mathbf{x}) = (\Phi_1(\mathbf{x}), \Phi_2(\mathbf{x})) \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^{d_0}.$$

3. 若  $d_0^1 = d_0^2 =: d_0$ 、 $L_1 = L_2 =: L$  且  $d_{L+1}^1 = d_{L+1}^2 =: d_{L+1}$ ，则存在架构为  $(\sigma; d_0, d_1^1 + d_1^2, \dots, d_L^1 + d_L^2, d_{L+1})$  的神经网络  $\Phi_{\text{sum}}$ ，使得

$$\Phi_{\text{sum}}(\mathbf{x}) = \Phi_1(\mathbf{x}) + \Phi_2(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^{d_0}.$$

4. 若  $d_{L_1+1}^1 = d_0^2$ ，则存在架构为  $(\sigma; d_0^1, d_1^1, \dots, d_{L_1}^1, d_1^2, \dots, d_{L_2+1}^2)$  的神经网络  $\Phi_{\text{comp}}$ ，使得

$$\Phi_{\text{comp}}(\mathbf{x}) = \Phi_2 \circ \Phi_1(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^{d_0^1}.$$

## 2.2 规模的概念

神经网络提供了参数化函数的框架。我们的最终目标是找到一个拟合某种潜在输入—输出关系的神经网络。如前所述，架构（深度、宽度与激活函数）通常预先选定并视为固定。训练神经网络时，某种算法适当地调整其参数（权重和偏置）。依应用而定，除上述架构选择外，可能还需要对权重和偏置施加其他限制。下面两种限制经常出现：

- 权重共享 (weight sharing): 约束权重矩阵 (或偏置向量) 的某些指定分量相等. 形式上, 就是施加  $W_{k,l}^{(i)} = W_{s,t}^{(j)}$  这类条件, 即第  $i$  个权重矩阵的  $(k, l)$  分量等于第  $j$  个权重矩阵的  $(s, t)$  分量. 记这一假设为  $(i, k, l) \sim (j, s, t)$ ; 这也体现了一个平凡事实, 即 “ $\sim$ ” 是等价关系. 训练时, 共享权重会联合更新: 一个权重的任何变化都会同时施加到该等价类中的所有其他权重. 权重共享也可用于偏置向量的分量.
- 稀疏性 (sparsity): 对权重矩阵 (或偏置向量) 施加稀疏结构. 具体地, 预先对某些  $(k, l, i)$  设定  $W_{k,l}^{(i)} = 0$ , 即要求第  $i$  个权重矩阵的  $(k, l)$  分量为 0. 这些零分量视为固定, 在训练中不作调整. 条件  $W_{k,l}^{(i)} = 0$  对应于第  $i-1$  层的节点  $l$  不作为第  $i$  层节点  $k$  的输入. 若把神经网络表示为图, 这通过不连接相应节点来表示. 也可以对偏置向量施加稀疏性. 数学上, 可引入由零和一组成的稀疏向量  $\mathbf{s}$ , 并考察网络  $\Phi(\mathbf{x}, \mathbf{w} \odot \mathbf{s})$ , 其中  $\odot$  表示逐分量乘法.

这两种限制都会减少神经网络中可学习参数的数目. 参数数目可以看作所表示函数类复杂度的一种度量. 因而, 我们引入  $\text{size}(\Phi)$ , 表示可学习参数的数目. 形式上 (以  $|S|$  表示集合  $S$  的基数):

**定义 2.4:** 设  $\Phi$  如定义 2.1 所示. 则  $\Phi$  的规模 (size) 定义为

$$\text{size}(\Phi) := \left| \left( \{(i, k, l) \mid W_{k,l}^{(i)} \neq 0\} \cup \{(i, k) \mid b_k^{(i)} \neq 0\} \right) / \sim \right|. \quad (2.4)$$

## 2.3 激活函数

激活函数是神经网络的关键组成部分, 因为它们为模型引入非线性. 若使用仿射激活函数, 所得神经网络函数也仍是仿射函数, 因而其表示能力极为有限.

激活函数的选择可能显著影响性能, 但似乎不存在普遍最优的选择. 下面讨论几种重要激活函数, 并指出与它们相关的一些常见问题.




图 2.2: 不同的激活函数.

Sigmoid 激活函数 (sigmoid activation function) 定义为

$$\sigma_{\text{sig}}(x) = \frac{1}{1 + e^{-x}} \quad \text{对 } x \in \mathbb{R},$$

如图 2.2(a) 所示. 它的输出位于零与一之间, 因此可解释为概率. Sigmoid 是光滑函数, 因而可以应用基于梯度的训练.

其缺点是, 当  $|x| \rightarrow \infty$  时, 导数变得很小. 这会通过所谓的梯度消失问题 (vanishing gradient problem) 影响学习. 考虑简单神经网络  $\Phi_n(x) = \sigma \circ \cdots \circ \sigma(x + b)$ , 其中  $\sigma$  复合  $n \in \mathbb{N}$  次,  $b \in \mathbb{R}$  是偏置. 它关于  $b$  的导数为

$$\frac{d}{db} \Phi_n(x) = \sigma'(\Phi_{n-1}(x)) \frac{d}{db} \Phi_{n-1}(x).$$

若  $\sup_{x \in \mathbb{R}} |\sigma'(x)| \leq 1 - \delta$ , 则由归纳法,  $|\frac{d}{db} \Phi_n(x)| \leq (1 - \delta)^n$ . 对导数一致大于一的激活函数, 会出现相反效应. 这说明,  $\Phi_n(x, b)$  关于  $b$  的导数在各层间传播时可能指数变小或指数变大. 这种现象称为梯度消失或爆炸效应 (vanishing or exploding gradient effect); 即便激活函数不满足上述一致界, 它也会发生. 不过, Sigmoid 激活函数存在梯度极小的区域, 因此会显著加剧梯度消失效应.

ReLU 定义为

$$\sigma_{\text{ReLU}}(x) = \max\{x, 0\} \quad \text{对 } x \in \mathbb{R},$$

如图 2.2(b) 所示. 它是分段线性的, 并且由于形式简单, 计算极其高效. 它是实际中最常用的激活函数之一. 因为其导数总是零或一, 所以它受到梯度消失问题的影响不如 Sigmoid 严重. 然而, ReLU 可能遇到所谓的神经元死亡问题 (dead neuron problem). 考虑依赖偏置  $b \in \mathbb{R}$  的神经网络

$$\Phi(x) = \sigma_{\text{ReLU}}(b - \sigma_{\text{ReLU}}(x)) \quad \text{对 } x \in \mathbb{R}.$$

若  $b < 0$ , 则对所有  $x \in \mathbb{R}$  都有  $\Phi(x) = 0$ . 因而, 对应于第二次应用  $\sigma_{\text{ReLU}}$  的神经元产生常数信号. 此外, 当  $b < 0$  时, 对所有  $x \in \mathbb{R}$  都有  $\frac{d}{db} \Phi(x) = 0$ . 于是, 每个负的  $b$  都给出经验风险的一个驻点, 基于梯度的方法无法继续训练参数  $b$ . 因而称该神经元为死亡神经元 (dead neuron).

ReLU 与 Sigmoid 的一个重要差别是 ReLU 在 0 处不可微. SiLU 激活函数 (SiLU activation function) (也称为 “swish”) 可以解释为 ReLU 的光滑逼近. 它定义为

$$\sigma_{\text{SiLU}}(x) := x \sigma_{\text{sig}}(x) = \frac{x}{1 + e^{-x}} \quad \text{对 } x \in \mathbb{R},$$

如图 2.2(b) 所示. 还有多种模拟 ReLU 的光滑激活函数, 包括 Softplus  $x \mapsto \log(1 + \exp(x))$ , GELU (Gaussian Error Linear Unit)  $x \mapsto xF(x)$ ——其中  $F(x)$  表示标准正态分布的累积分布函数——以及 Mish  $x \mapsto x \tanh(\log(1 + \exp(x)))$ .

这种 ReLU 变体旨在处理神经元死亡问题. 对某个  $a \in (0, 1)$ , 参数化 ReLU (parametric ReLU) 定义为

$$\sigma_a(x) = \max\{x, ax\} \quad \text{对 } x \in \mathbb{R},$$

图 2.2(c) 展示了三个不同的  $a$  值. 由于  $\sigma$  的输出不像 ReLU 那样含有平坦区域, ReLU 死亡问题得到缓解. 若  $a$  取得不过小, 则其梯度消失问题也比 Sigmoid 轻. 实际中, 需要根据应用对附加参数  $a$  作细致调节. 与 ReLU 一样, 参数化 ReLU 在 0 处不可微.

## 参考文献与延伸阅读

神经网络概念最早由 McCulloch 和 Pitts 在文献 [196] 中提出. 后来, Rosenblatt [261] 提出了感知机, 这是一种权重可调的人工神经元, 并构成多层感知机 (全连接前馈神经网络) 的基础. 第 2.3 节简要提到的梯度消失问题, Hochreiter 在其学位论文 [131] 中讨论过, 后来又见于文献 [29, 133].

## 习题

2.5. 证明命题 2.3.

2.6. 本题说明 ReLU 与参数化 ReLU 生成相似的神经网络函数集合. 固定  $a > 0$ .

1. 求一组权重矩阵和偏置向量, 使以 ReLU 激活函数  $\sigma_{\text{ReLU}}$  构成的相应神经网络  $\Phi_1$  满足: 对所有  $x \in \mathbb{R}$ ,  $\Phi_1(x) = \sigma_a(x)$ .
2. 求一组权重矩阵和偏置向量, 使以参数化 ReLU 激活函数  $\sigma_a$  构成的相应神经网络  $\Phi_2$  满足: 对所有  $x \in \mathbb{R}$ ,  $\Phi_2(x) = \sigma_{\text{ReLU}}(x)$ .
3. 由此推出, 每个 ReLU 神经网络都能表示为 Leaky ReLU 神经网络, 反之亦然.

2.7. 设  $d \in \mathbb{N}$ ,  $\Phi_1$  是输入维数为  $d$ 、输出维数为 1、以 ReLU 为激活函数的神经网络;  $\Phi_2$  是输入维数为  $d$ 、输出维数为 1、以 Sigmoid 为激活函数的神经网络. 证明: 若  $\Phi_1 = \Phi_2$ , 则  $\Phi_1$  是常函数.

2.8. 本题说明, 对 Sigmoid 激活函数而言, 类似死亡神经元的行为非常罕见. 设  $\Phi$  是以 Sigmoid 为激活函数的神经网络, 并假设  $\Phi$  是常函数. 证明: 对每个  $\varepsilon > 0$ , 都存在与  $\Phi$  架构相同的非常值神经网络  $\tilde{\Phi}$ , 使得对所有  $\ell = 0, \dots, L$  都有

$$\|\mathbf{W}^{(\ell)} - \tilde{\mathbf{W}}^{(\ell)}\| \leq \varepsilon, \quad \|\mathbf{b}^{(\ell)} - \tilde{\mathbf{b}}^{(\ell)}\| \leq \varepsilon,$$

其中  $\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}$  是  $\Phi$  的权重和偏置,  $\tilde{\mathbf{W}}^{(\ell)}, \tilde{\mathbf{b}}^{(\ell)}$  是  $\tilde{\Phi}$  的权重和偏置. 证明 ReLU 神经网络不满足这样的陈述. Leaky ReLU 的情形如何?



## 万能逼近

在第 2 章引入神经网络之后，自然要追问它们究竟具有怎样的能力。特别地，神经网络能够表示的函数类型是否存在内在限制？是否有某类函数根本无法由神经网络逼近？若答案为是，神经网络就只是专用工具，正如线性回归适合线性关系，却不适合具有非线性关系的数据。

本章主要遵循文献 [180]，说明情况并非如此：神经网络确实是一种万能工具。更确切地说，只要架构足够大且足够复杂，它们几乎可以逼近一切合理的输入-输出关系。以下各节将严格表述并证明这一论断。

### 3.1 一个万能逼近定理

为了分析神经网络可以逼近哪些函数，我们先研究紧集上连续函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  的一致逼近。为此，首先引入紧收敛的概念。

**定义 3.1:** 设  $d \in \mathbb{N}$ 。若对每个紧集  $K \subseteq \mathbb{R}^d$  都有  $\lim_{n \rightarrow \infty} \sup_{x \in K} |f_n(x) - f(x)| = 0$ 。则称函数序列  $f_n: \mathbb{R}^d \rightarrow \mathbb{R}$  ( $n \in \mathbb{N}$ ) 紧收敛 (compact convergence) 到函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，并记作  $f_n \xrightarrow{cc} f$ 。

**定义 3.2:** 设  $d \in \mathbb{N}$ 、 $k \in \mathbb{N}_0 \cup \{\infty\}$  且  $\Omega \subseteq \mathbb{R}^d$ 。以  $C^k(\Omega)$  表示所有函数  $f: \Omega \rightarrow \mathbb{R}$  的集合，其中直到  $k$  阶的全部偏导数都存在于  $\Omega$  的内部，并且能够连续延拓到整个  $\Omega$ 。此外，当  $k < \infty$  时，定义

$$\|f\|_{C^k(\Omega)} := \sup_{x \in \Omega} \sup_{\substack{\alpha \in \mathbb{N}_0^d \\ |\alpha| \leq k}} |D^\alpha f(x)|,$$

当  $k = \infty$  时，内层上确界取遍所有  $\alpha \in \mathbb{N}_0^d$ 。

下文始终给  $C^0(\mathbb{R}^d)$  配备定义 3.1 的拓扑 (另见习题 3.24)，并给  $C^0(D)$  等子集配备子空间拓扑。例如，若  $D \subseteq \mathbb{R}^d$  有界，则  $C^0(D)$  中的收敛是指一致收敛，即

$$\lim_{n \rightarrow \infty} \sup_{x \in D} |f_n(x) - f(x)| = 0.$$

#### 3.1.1 万能逼近族

如前所述，我们希望说明深度神经网络可以在定义 3.1 的意义下逼近每个连续函数。满足这一性质的函数集合称为万能逼近族。

**定义 3.3:** 设  $d \in \mathbb{N}$ 。若对每个  $\varepsilon > 0$ 、每个紧集  $K \subseteq \mathbb{R}^d$  和每个  $f \in C^0(\mathbb{R}^d)$ ，都存在  $g \in \mathcal{H}$  使得  $\sup_{x \in K} |f(x) - g(x)| < \varepsilon$ ，则称由  $\mathbb{R}^d$  到  $\mathbb{R}$  的函数组成的集合  $\mathcal{H}$  是  $C^0(\mathbb{R}^d)$  的万能逼近族 (universal approximator)。



对由  $\mathbb{R}^d$  到  $\mathbb{R}$  的函数（不必连续）组成的集合  $\mathcal{H}$ ，以  $\overline{\mathcal{H}}^{\text{cc}}$  表示它关于紧收敛的闭包。

下面的命题刻画万能逼近族与紧收敛闭包之间的关系。

**命题 3.4:** 设  $d \in \mathbb{N}$ ， $\mathcal{H}$  是由  $\mathbb{R}^d$  到  $\mathbb{R}$  的函数组成的集合。则  $\mathcal{H}$  是  $C^0(\mathbb{R}^d)$  的万能逼近族，当且仅当  $C^0(\mathbb{R}^d) \subseteq \overline{\mathcal{H}}^{\text{cc}}$ 。

**证明:** 先设  $\mathcal{H}$  是万能逼近族，并固定  $f \in C^0(\mathbb{R}^d)$ 。对  $n \in \mathbb{N}$ ，令  $K_n := [-n, n]^d \subseteq \mathbb{R}^d$ 。则对每个  $n \in \mathbb{N}$ ，存在  $f_n \in \mathcal{H}$  使得  $\sup_{x \in K_n} |f_n(x) - f(x)| < 1/n$ 。对每个紧集  $K \subseteq \mathbb{R}^d$ ，都存在  $n_0$ ，使得所有  $n \geq n_0$  都有  $K \subseteq K_n$ ，故  $f_n \xrightarrow{\text{cc}} f$ 。反向命题由定义立即得到。□

证明一个集合是万能逼近族的关键工具是 Stone-Weierstrass 定理，例如参见文献 [265, Sec. 5.7]。

**定理 3.5 (Stone-Weierstrass):** 设  $d \in \mathbb{N}$ ， $K \subseteq \mathbb{R}^d$  为紧集，且  $\mathcal{H} \subseteq C^0(K, \mathbb{R})$  满足：

- (a) 对每个  $x \in K$ ，存在  $f \in \mathcal{H}$  使得  $f(x) \neq 0$ ；
- (b) 对每个  $x \neq y \in K$ ，存在  $f \in \mathcal{H}$  使得  $f(x) \neq f(y)$ ，
- (c)  $\mathcal{H}$  是函数代数，即对加法、乘法和标量乘法封闭。

则  $\mathcal{H}$  在  $C^0(K)$  中稠密。

**例 3.6 (多项式构成万能逼近族):** 对多重指标  $\alpha = (\alpha_1, \dots, \alpha_d) \in \mathbb{N}_0^d$  和向量  $x = (x_1, \dots, x_d) \in \mathbb{R}^d$ ，记  $x^\alpha := \prod_{j=1}^d x_j^{\alpha_j}$ 。令  $|\alpha| := \sum_{j=1}^d \alpha_j$ ，并记

$$\mathcal{P}_n := \text{span}\{x^\alpha \mid \alpha \in \mathbb{N}_0^d, |\alpha| \leq n\}$$

即  $\mathcal{P}_n$  是次数不超过  $n$  的实系数多项式空间。容易验证， $\mathcal{P} := \bigcup_{n \in \mathbb{N}} \mathcal{P}_n(\mathbb{R}^d)$  在每个紧集  $K \subseteq \mathbb{R}^d$  上满足定理 3.5 的假设。因而多项式空间  $\mathcal{P}$  是  $C^0(\mathbb{R}^d)$  的万能逼近族；由命题 3.4， $\mathcal{P}$  在  $C^0(\mathbb{R}^d)$  中稠密。需要强调底空间维数时，下文也分别写作  $\mathcal{P}_n(\mathbb{R}^d)$  和  $\mathcal{P}(\mathbb{R}^d)$ 。◇

### 3.1.2 浅层神经网络

建立必要的形式体系后，现在可以说明：在激活函数满足某些温和条件时，任意宽度的浅层神经网络构成万能逼近族。本节结果及其证明遵循文献 [180]。先为特定架构所实现的全部函数组成的集合引入记号。

**定义 3.7:** 设  $d, m, L, n \in \mathbb{N}$  且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 。输入维数为  $d$ 、输出维数为  $m$ 、深度不超过  $L$ 、宽度不超过  $n$  且激活函数为  $\sigma$  的神经网络所实现的全部函数组成的集合记为

$$\mathcal{N}_d^m(\sigma; L, n) := \{\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^m \mid \Phi \text{ 如定义 2.1 所示, } \text{depth}(\Phi) \leq L, \text{width}(\Phi) \leq n\}.$$

此外，

$$\mathcal{N}_d^m(\sigma; L) := \bigcup_{n \in \mathbb{N}} \mathcal{N}_d^m(\sigma; L, n).$$

下文要求激活函数  $\sigma$  属于分段连续且局部有界的函数集合

$$\mathcal{M} := \left\{ \sigma \in L_{\text{loc}}^\infty(\mathbb{R}) \mid \begin{array}{l} \text{存在把 } \mathbb{R} \text{ 分割开的区间 } I_1, \dots, I_M, \\ \text{且对所有 } j = 1, \dots, M \text{ 都有 } \sigma \in C^0(I_j) \end{array} \right\}. \quad (3.1)$$

这里  $M \in \mathbb{N}$  有限, 并约定区间  $I_j$  具有正的 (也可能无限的) Lebesgue 测度, 即  $I_j$  不能是空集或单点. 因而  $\sigma$  是分段连续函数, 至多在有限多个点不连续.

**例 3.8:** 属于  $\mathcal{M}$  的激活函数特别包括所有连续非多项式函数, 因而包含第 2.3 节讨论的 ReLU、SiLU 和 Sigmoid 等实际相关的激活函数. 此时可取  $M = 1$  和  $I_1 = \mathbb{R}$ . 不连续的例子包括 Heaviside 函数  $x \mapsto \mathbf{1}_{x>0}$  (在此语境中也称“感知机”) 以及  $x \mapsto \mathbf{1}_{x>0} \sin(1/x)$ ; 二者都属于  $\mathcal{M}$ , 可取  $M = 2$ 、 $I_1 = (-\infty, 0]$  和  $I_2 = (0, \infty)$ . 函数  $x \mapsto 1/x$  则因不局部有界而被排除.  $\diamond$

本小节余下部分证明下面这个已经多次预告的定理.

**定理 3.9:** 设  $d \in \mathbb{N}$  且  $\sigma \in \mathcal{M}$ . 则  $\mathcal{N}_d^1(\sigma; 1)$  是  $C^0(\mathbb{R}^d)$  的万能逼近族, 当且仅当  $\sigma$  不是多项式.

**注 3.10:** 在推论 3.19 和习题 3.28 中将看到, 关于适当的范数, 神经网络也能以任意精度逼近不连续函数.  $\diamond$

Leshno、Lin、Pinkus 与 Schocken 的万能逼近定理 [180] (定理 3.9 是其特例) 实际上针对更大的集合  $\mathcal{M}$  表述, 允许激活函数在一个 Lebesgue 零测集 (不一定有限) 上不连续. 这里采用上述简化情形, 从而避开部分技术细节, 同时保留主要思想. 证明策略是验证以下三个断言:

1. **约化到一元目标函数:** 若  $C^0(\mathbb{R}^1) \subseteq \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ , 则  $C^0(\mathbb{R}^d) \subseteq \overline{\mathcal{N}_d^1(\sigma; 1)}^{\text{cc}}$ ;
2. **约化到光滑激活函数:** 若  $\sigma \in C^\infty(\mathbb{R})$  不是多项式, 则  $C^0(\mathbb{R}^1) \subseteq \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ ;
3. **一般情形:** 若  $\sigma \in \mathcal{M}$  不是多项式, 则存在  $\tilde{\sigma} \in C^\infty(\mathbb{R}) \cap \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ , 且它不是多项式.

注意到  $\tilde{\sigma} \in \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$  implies  $\overline{\mathcal{N}_1^1(\tilde{\sigma}; 1)}^{\text{cc}} \subseteq \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ , 便容易看出, 这三个断言与命题 3.4 共同给出定理 3.9 中的“ $\Leftarrow$ ”方向. 反向命题容易验证, 留作习题 3.25.

先证明断言 1 的一个更一般版本, 并依照文献 [187, Theorem 2.1] 把问题约化到一维情形.

**引理 3.11:** 设  $\mathcal{H}$  是  $C^0(\mathbb{R})$  的万能逼近族. 则对每个  $d \in \mathbb{N}$ ,

$$\text{span}\{x \mapsto g(w \cdot x) \mid w \in \mathbb{R}^d, g \in \mathcal{H}\}$$

是  $C^0(\mathbb{R}^d)$  的万能逼近族.

**证明:** 对  $k \in \mathbb{N}_0$ , 以  $\mathbb{H}_k$  表示所有  $k$  次齐次多项式组成的空间, 即

$$\mathbb{H}_k := \text{span} \{ \mathbb{R}^d \ni x \mapsto x^\alpha \mid \alpha \in \mathbb{N}_0^d, |\alpha| = k \}.$$

我们断言, 对所有  $k \in \mathbb{N}_0$  都有

$$\mathbb{H}_k \subseteq \overline{\text{span}\{\mathbb{R}^d \ni \mathbf{x} \mapsto g(\mathbf{w} \cdot \mathbf{x}) \mid \mathbf{w} \in \mathbb{R}^d, g \in \mathcal{H}\}}^{\text{cc}} =: X \quad (3.2)$$

这说明所有多元多项式都属于  $X$ . 再应用 Stone–Weierstrass 定理 (比较例 3.6) 和命题 3.4 即可完成证明.

对每个满足  $|\alpha| = |\beta| = k$  的  $\alpha, \beta \in \mathbb{N}_0^d$ , 有  $D^\beta \mathbf{x}^\alpha = \delta_{\beta, \alpha} \alpha!$ , 其中  $\alpha! := \prod_{j=1}^d \alpha_j!$ , 并且  $\beta = \alpha$  时  $\delta_{\beta, \alpha} = 1$ , 否则为 0. 因为  $\{\mathbf{x} \mapsto \mathbf{x}^\alpha \mid |\alpha| = k\}$  是  $\mathbb{H}_k$  的一组基, 故  $\{D^\alpha \mid |\alpha| = k\}$  是其拓扑对偶  $\mathbb{H}'_k$  的一组基. 因而每个线性泛函  $l \in \mathbb{H}'_k$  都可写成  $l = p(D)$ , 其中某个  $p \in \mathbb{H}_k$ , 这里  $D$  表示微分算子.

由多项式公式,

$$(\mathbf{w} \cdot \mathbf{x})^k = \left( \sum_{j=1}^d w_j x_j \right)^k = \sum_{\{\alpha \in \mathbb{N}_0^d \mid |\alpha| = k\}} \frac{k!}{\alpha!} \mathbf{w}^\alpha \mathbf{x}^\alpha.$$

所以  $(\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k) \in \mathbb{H}_k$ . 此外, 对每个  $l = p(D) \in \mathbb{H}'_k$  和所有  $\mathbf{w} \in \mathbb{R}^d$ , 有

$$l(\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k) = k! p(\mathbf{w}).$$

因此, 若对所有  $\mathbf{w} \in \mathbb{R}^d$  都有  $l(\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k) = p(D)(\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k) = 0$ , 则  $p \equiv 0$ , 从而  $l \equiv 0$ .

这蕴含  $\text{span}\{\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k \mid \mathbf{w} \in \mathbb{R}^d\} = \mathbb{H}_k$ . 事实上, 若存在  $h \in \mathbb{H}_k$  不属于  $\text{span}\{\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k \mid \mathbf{w} \in \mathbb{R}^d\}$ , 则由 Hahn–Banach 定理 (见定理 B.10), 存在  $\mathbb{H}'_k$  中的非零泛函, 在  $\text{span}\{\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k \mid \mathbf{w} \in \mathbb{R}^d\}$  上恒为零, 这与前述观察矛盾.

由  $\mathcal{H}$  的万能性, 不难看出对所有  $\mathbf{w} \in \mathbb{R}^d$  都有  $\mathbf{x} \mapsto (\mathbf{w} \cdot \mathbf{x})^k \in X$ . 因而对所有  $k \in \mathbb{N}_0$  都有  $\mathbb{H}_k \subseteq X$ .  $\square$

由上面的引理, 要验证  $\mathcal{N}_d^1(\sigma; 1)$  是万能逼近族, 只需证明  $\mathcal{N}_1^1(\sigma; 1)$  是万能逼近族. 先对 S 形激活函数证明这一点.

**定义 3.12:** 若  $\sigma \in C^0(\mathbb{R})$ ,  $\lim_{x \rightarrow \infty} \sigma(x) = 1$  且  $\lim_{x \rightarrow -\infty} \sigma(x) = 0$ , 则称激活函数  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  为 S 形的 (sigmoidal).

对 S 形激活函数, 现在可以得到一元情形下的万能性.

**引理 3.13:** 设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  单调递增且为 S 形. 则  $C^0(\mathbb{R}) \subseteq \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ .

引理 3.13 的证明留作习题 3.26. 引理 3.11 与引理 3.13 证明了  $\sigma$  单调递增且为 S 形时定理 3.9 成立. 对一般情形, 继续证明断言 2, 考虑  $C^\infty$  激活函数.

**引理 3.14:** 若  $\sigma \in C^\infty(\mathbb{R})$  且  $\sigma$  不是多项式, 则  $\mathcal{N}_1^1(\sigma; 1)$  在  $C^0(\mathbb{R})$  中稠密.

**证明:** 记

$$X := \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}.$$

我们再次证明所有多项式都属于  $X$ , 再应用 Stone–Weierstrass 定理即得结论.

固定  $b \in \mathbb{R}$ , 并对所有  $x, w \in \mathbb{R}$  记  $f_x(w) := \sigma(wx + b)$ . 由 Taylor 定理, 当  $h \neq 0$  时,

$$\begin{aligned} \frac{\sigma((w+h)x+b) - \sigma(wx+b)}{h} &= \frac{f_x(w+h) - f_x(w)}{h} \\ &= f'_x(w) + \frac{h}{2} f''_x(\xi) \\ &= f'_x(w) + \frac{h}{2} x^2 \sigma''(\xi x + b) \end{aligned} \quad (3.3)$$

其中某个  $\xi = \xi(h)$  位于  $w$  与  $w+h$  之间. 注意, 左端作为  $x$  的函数属于  $\mathcal{N}_1^1(\sigma; 1)$ . 因为  $\sigma'' \in C^0(\mathbb{R})$ , 对每个紧集  $K \subseteq \mathbb{R}$ ,

$$\sup_{x \in K} \sup_{|h| \leq 1} |x^2 \sigma''(\xi(h)x + b)| \leq \sup_{x \in K} \sup_{\eta \in [w-1, w+1]} |x^2 \sigma''(\eta x + b)| < \infty.$$

令  $h \rightarrow 0$ , 式 (3.3) 作为  $x$  的函数便在  $K$  上一致收敛到  $K \ni x \mapsto f'_x(w)$ . 由于  $K$  任意,  $x \mapsto f'_x(w)$  属于  $X$ . 对  $f_x^{(k-1)}(w)$  归纳应用同一论证, 得到对所有  $k \in \mathbb{N}$  和  $w \in \mathbb{R}$ ,  $x \mapsto f_x^{(k)}(w)$  都属于  $X$ . 注意  $f_x^{(k)}(w) = x^k \sigma^{(k)}(wx + b)$ . 因为  $\sigma$  不是多项式, 对每个  $k \in \mathbb{N}$  都存在  $b_k \in \mathbb{R}$  使得  $\sigma^{(k)}(b_k) \neq 0$ . 取  $w = 0$ , 便有  $x \mapsto \sigma^{(k)}(b_k)x^k$  属于  $X$ , 因而  $x \mapsto x^k$  也属于  $X$ .  $\square$

最后证明断言 3:  $\mathcal{N}_1^1(\sigma; 1)$  的闭包中至少存在一个非多项式的  $C^\infty(\mathbb{R})$  函数. 论证分为两个引理. 下文以  $C_c^\infty(\mathbb{R})$  表示具有紧支集的  $C^\infty(\mathbb{R})$  函数集合; 对两个函数  $f, g: \mathbb{R} \rightarrow \mathbb{R}$ , 定义它们的卷积 (convolution) 为

$$f * g(x) := \int_{\mathbb{R}} f(x-y)g(y) \, dx \quad \text{对所有 } x \in \mathbb{R}. \quad (3.4)$$

**引理 3.15:** 设  $\sigma \in \mathcal{M}$ . 则对每个  $\varphi \in C_c^\infty(\mathbb{R})$ , 都有  $\sigma * \varphi \in \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ .

**证明:** 固定  $\varphi \in C_c^\infty(\mathbb{R})$ , 并取  $a > 0$  使得  $\text{supp } \varphi \subseteq [-a, a]$ . 对  $j = 0, \dots, n$ , 记  $y_j := -a + 2aj/n$ , 并对  $x \in \mathbb{R}$  定义

$$f_n(x) := \frac{2a}{n} \sum_{j=0}^{n-1} \sigma(x - y_j) \varphi(y_j).$$

显然  $f_n \in \mathcal{N}_1^1(\sigma; 1)$ . 我们证明当  $n \rightarrow \infty$  时  $f_n \xrightarrow{\text{cc}} \sigma * \varphi$ . 为此, 固定任意  $b > 0$ , 验证  $f_n$  在区间  $[-b, b]$  上一致收敛到  $\sigma * \varphi$ .

对  $x \in [-b, b]$ ,

$$|\sigma * \varphi(x) - f_n(x)| \leq \sum_{j=0}^{n-1} \left| \int_{y_j}^{y_{j+1}} \sigma(x-y) \varphi(y) - \sigma(x-y_j) \varphi(y_j) \, dy \right|. \quad (3.5)$$

固定  $\varepsilon \in (0, 1)$ . 因为  $\sigma \in \mathcal{M}$ , 存在  $z_1, \dots, z_M \in \mathbb{R}$ , 使得  $\sigma$  在  $\mathbb{R} \setminus \{z_1, \dots, z_M\}$  上连续 (比较式 (3.1)). 令  $D_\varepsilon := \bigcup_{j=1}^M (z_j - \varepsilon, z_j + \varepsilon)$ ; 则  $\sigma$  在紧集  $K_\varepsilon := [-a-b, a+b] \cap D_\varepsilon^c$  上一致连续. 令  $J_c \cup J_d = \{0, \dots, n-1\}$  是一个依赖于  $x$  的分割, 使得  $j \in J_c$  当且

仅当  $[x - y_{j+1}, x - y_j] \subseteq K_\varepsilon$ . 因而  $j \in J_d$  意味着存在  $i \in \{1, \dots, M\}$ , 使得  $z_i$  到  $[x - y_{j+1}, x - y_j]$  的距离至多为  $\varepsilon$ . 由于区间  $[x - y_{j+1}, x - y_j]$  的长度为  $2a/n$ , 可估计为

$$\begin{aligned} \sum_{j \in J_d} y_{j+1} - y_j &= \left| \bigcup_{j \in J_d} [x - y_{j+1}, x - y_j] \right| \\ &\leq \left| \bigcup_{i=1}^M \left[ z_i - \varepsilon - \frac{2a}{n}, z_i + \varepsilon + \frac{2a}{n} \right] \right| \\ &\leq M \cdot \left( 2\varepsilon + \frac{4a}{n} \right), \end{aligned}$$

其中  $|A|$  表示可测集  $A \subseteq \mathbb{R}$  的 Lebesgue 测度. 接着, 由  $\sigma$  的局部有界性和  $\varphi \in C_c^\infty$ , 有  $\sup_{|y| \leq a+b} |\sigma(y)| + \sup_{|y| \leq a} |\varphi(y)| =: \gamma < \infty$ . 因此,

$$\begin{aligned} &|\sigma * \varphi(x) - f_n(x)| \\ &\leq \sum_{j \in J_c \cup J_d} \left| \int_{y_j}^{y_{j+1}} \sigma(x-y)\varphi(y) - \sigma(x-y_j)\varphi(y_j) dy \right| \\ &\leq 2\gamma^2 M \cdot \left( 2\varepsilon + \frac{4a}{n} \right) \\ &\quad + 2a \sup_{j \in J_c} \max_{y \in [y_j, y_{j+1}]} |\sigma(x-y)\varphi(y) - \sigma(x-y_j)\varphi(y_j)|. \end{aligned} \tag{3.6}$$

最后一个最大值中的项可估计为

$$\begin{aligned} &|\sigma(x-y)\varphi(y) - \sigma(x-y_j)\varphi(y_j)| \\ &\leq |\sigma(x-y) - \sigma(x-y_j)| |\varphi(y)| + |\sigma(x-y_j)| |\varphi(y) - \varphi(y_j)| \\ &\leq \gamma \cdot \left( \sup_{\substack{z_1, z_2 \in K_\varepsilon \\ |z_1 - z_2| \leq \frac{2a}{n}}} |\sigma(z_1) - \sigma(z_2)| + \sup_{\substack{z_1, z_2 \in [-a, a] \\ |z_1 - z_2| \leq \frac{2a}{n}}} |\varphi(z_1) - \varphi(z_2)| \right). \end{aligned}$$

最后,  $\sigma$  在  $K_\varepsilon$  上以及  $\varphi$  在  $[-a, a]$  上的一致连续性说明, 当  $n \rightarrow \infty$  时, 最后一项对所有  $x \in [-b, b]$  一致趋于 0. 因此存在与  $\varepsilon, x$  无关的  $C < \infty$  以及与  $x$  无关的  $n_\varepsilon \in \mathbb{N}$ , 使得对所有  $n \geq n_\varepsilon$ , 式 (3.6) 中的项不超过  $C\varepsilon$ . 由于  $\varepsilon$  任意, 断言得证.  $\square$

**引理 3.16:** 若  $\sigma \in \mathcal{M}$ , 且对所有  $\varphi \in C_c^\infty(\mathbb{R})$ ,  $\sigma * \varphi$  都是多项式, 则  $\sigma$  是多项式.

**证明:** 固定  $-\infty < a < b < \infty$ , 并考虑  $C_c^\infty(a, b) := \{\varphi \in C^\infty(\mathbb{R}) \mid \text{supp } \varphi \subseteq [a, b]\}$ . 在  $C_c^\infty(a, b)$  上定义度量

$$\rho(\varphi, \psi) := \sum_{j \in \mathbb{N}_0} 2^{-j} \frac{|\varphi - \psi|_{C^j(a, b)}}{1 + |\varphi - \psi|_{C^j(a, b)}},$$

其中

$$|\varphi|_{C^j(a, b)} := \sup_{x \in [a, b]} |\varphi^{(j)}(x)|.$$

由于  $[a, b]$  上  $j$  次可微函数空间关于范数  $\sum_{i=0}^j |\cdot|_{C^i(a,b)}$  完备 (例如见文献 [130, Satz 104.3]), 空间  $C_c^\infty(a, b)$  关于度量  $\rho$  完备. 对  $k \in \mathbb{N}$ , 令

$$V_k := \{\varphi \in C_c^\infty(a, b) \mid \sigma * \varphi \in \mathcal{P}_k\},$$

其中  $\mathcal{P}_k := \text{span}\{\mathbb{R} \ni x \mapsto x^j \mid 0 \leq j \leq k\}$  表示次数不超过  $k$  的多项式空间. 则  $V_k$  关于度量  $\rho$  闭. 为此, 设  $\varphi_j \rightarrow \varphi^*$  关于  $\rho$  收敛且  $\varphi_j \in V_k$ ; 只需证明  $D^{k+1}(\sigma * \varphi^*) = 0$ , 从而  $\sigma * \varphi^*$  是多项式. 利用  $\varphi_j \in V_k$  时  $D^{k+1}(\sigma * \varphi_j) = 0$ 、卷积的线性, 以及在两端有定义时对可微  $g$  有  $D^{k+1}(\sigma * g) = \sigma * D^{k+1}(g)$ , 得到

$$\begin{aligned} & \sup_{x \in [a, b]} |D^{k+1}(\sigma * \varphi^*)(x)| \\ &= \sup_{x \in [a, b]} |\sigma * D^{k+1}(\varphi^* - \varphi_j)(x)| \\ &\leq |b - a| \sup_{z \in [a-b, b-a]} |\sigma(z)| \cdot \sup_{x \in [a, b]} |D^{k+1}(\varphi_j - \varphi^*)(x)|. \end{aligned}$$

由于  $\sigma$  局部有界, 右端在  $j \rightarrow \infty$  时趋于 0.

由假设,

$$\bigcup_{k \in \mathbb{N}} V_k = C_c^\infty(a, b).$$

Baire 范畴定理 (定理 B.6) 蕴含: 存在依赖于  $a, b$  的  $k_0 \in \mathbb{N}$ , 使得  $V_{k_0}$  包含  $C_c^\infty(a, b)$  的一个开子集. 因为  $V_{k_0}$  是向量空间, 必有  $V_{k_0} = C_c^\infty(a, b)$ .

现在证明对每个  $\varphi \in C_c^\infty(\mathbb{R})$  都有  $\varphi * \sigma \in \mathcal{P}_{k_0}$ ; 换言之, 可以选取与  $a, b$  无关的  $k_0 = k_0(a, b)$ . 先考虑平移  $s \in \mathbb{R}$ , 令  $\tilde{a} := a + s$ ,  $\tilde{b} := b + s$ . 取  $S(x) := x + s$ , 则对任意  $\varphi \in C_c^\infty(\tilde{a}, \tilde{b})$ , 有  $\varphi \circ S \in C_c^\infty(a, b)$ , 因而  $(\varphi \circ S) * \sigma \in \mathcal{P}_{k_0}$ . 由于  $(\varphi \circ S) * \sigma(x) = \varphi * \sigma(x + s)$ , 所以  $\varphi * \sigma \in \mathcal{P}_{k_0}$ . 再令  $-\infty < \tilde{a} < \tilde{b} < \infty$  任意. 对任何整数  $n > (\tilde{b} - \tilde{a})/(b - a)$ , 可用  $n \in \mathbb{N}$  个长度均为  $b - a$  的相交开区间  $(a_1, b_1), \dots, (a_n, b_n)$  覆盖  $(\tilde{a}, \tilde{b})$ . 任意  $\varphi \in C_c^\infty(\tilde{a}, \tilde{b})$  都可写成  $\varphi = \sum_{j=1}^n \varphi_j$ , 其中  $\varphi_j \in C_c^\infty(a_j, b_j)$ . 于是  $\varphi * \sigma = \sum_{j=1}^n \varphi_j * \sigma \in \mathcal{P}_{k_0}$ , 故对每个  $\varphi \in C_c^\infty(\mathbb{R})$  都有  $\varphi * \sigma \in \mathcal{P}_{k_0}$ .

最后, 习题 3.27 蕴含  $\sigma \in \mathcal{P}_{k_0}$ . □

现在可以汇总上述结果, 证明定理 3.9.

**定理 3.9 的证明:** 由习题 3.25, “ $\Rightarrow$ ” 方向成立.

反之, 设  $\sigma \in \mathcal{M}$  不是多项式. 由引理 3.16, 存在  $\varphi \in C_c^\infty(\mathbb{R})$ , 使得  $\sigma * \varphi$  不是多项式. 根据引理 3.15,  $\sigma * \varphi \in \overline{\mathcal{N}_1^1(\sigma; 1)}^{\text{cc}}$ . 再由引理 3.14,  $\mathcal{N}_1^1(\sigma; 1)$  是  $C^0(\mathbb{R})$  的万能逼近族.

最后, 由引理 3.11,  $\mathcal{N}_d^1(\sigma; 1)$  是  $C^0(\mathbb{R}^d)$  的万能逼近族. □

### 3.1.3 深度神经网络

定理 3.9 说明, 激活函数  $\sigma \in \mathcal{M} \setminus \mathcal{P}$  的单隐藏层神经网络具有万能逼近能力: 只要宽度足够, 它们就能在每个紧集上以任意精度逼近任意连续函数. 这一结果直接推广到



任意固定深度  $L \geq 1$  的神经网络. 思路是利用恒等函数可由浅层神经网络逼近这一事实: 把目标函数  $f$  的浅层网络逼近与一个或多个恒等函数的浅层网络逼近复合, 便得到  $f$  的深层网络逼近.

我们不直接应用[定理 3.9](#), 而先建立下面关于恒等函数逼近的命题. 它不要求  $\sigma \in \mathcal{M} \setminus \mathcal{P}$ , 而对激活函数作另一个温和假设. 这样可以给出构造性证明, 并得到神经网络规模的显式界; 这些界将在后文有用.

**命题 3.17:** 设  $d, L \in \mathbb{N}$ ,  $K \subseteq \mathbb{R}^d$  为紧集, 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  在某个开集上可微且非常值. 则对每个  $\varepsilon > 0$ , 存在神经网络  $\Phi \in \mathcal{N}_d^L(\sigma; L, d)$ , 使得

$$\|\Phi(\mathbf{x}) - \mathbf{x}\|_\infty < \varepsilon \quad \text{对所有 } \mathbf{x} \in K.$$

**证明:** 证明采用与[引理 3.14](#) 相同的思路, 用简单神经网络逼近激活函数的导数. 先设  $d \in \mathbb{N}$  且  $L = 1$ .

取  $x^* \in \mathbb{R}$ , 使得  $\sigma$  在  $x^*$  的一个邻域内可微且  $\sigma'(x^*) = \theta \neq 0$ . 再令  $\mathbf{x}^* = (x^*, \dots, x^*) \in \mathbb{R}^d$ . 对  $\lambda > 0$  定义

$$\Phi_\lambda(\mathbf{x}) := \frac{\lambda}{\theta} \sigma\left(\frac{\mathbf{x}}{\lambda} + \mathbf{x}^*\right) - \frac{\lambda}{\theta} \sigma(\mathbf{x}^*),$$

则对所有  $\mathbf{x} \in K$ ,

$$\Phi_\lambda(\mathbf{x}) - \mathbf{x} = \lambda \frac{\sigma(\mathbf{x}/\lambda + \mathbf{x}^*) - \sigma(\mathbf{x}^*)}{\theta} - \mathbf{x}. \quad (3.7)$$

若某个  $i \in \{1, \dots, d\}$  满足  $x_i = 0$ , 则式 (3.7) 说明  $(\Phi_\lambda(\mathbf{x}) - \mathbf{x})_i = 0$ . 否则

$$|(\Phi_\lambda(\mathbf{x}) - \mathbf{x})_i| = \frac{|x_i|}{|\theta|} \left| \frac{\sigma(x_i/\lambda + x^*) - \sigma(x^*)}{x_i/\lambda} - \theta \right|.$$

由导数的定义, 当  $\lambda \rightarrow \infty$  时,  $|(\Phi_\lambda(\mathbf{x}) - \mathbf{x})_i| \rightarrow 0$  对所有  $\mathbf{x} \in K$  和  $i \in \{1, \dots, d\}$  一致成立. 因而当  $\lambda \rightarrow \infty$  时,  $|\Phi_\lambda(\mathbf{x}) - \mathbf{x}| \rightarrow 0$  对所有  $\mathbf{x} \in K$  一致成立.

推广到  $L > 1$  很直接, 留作习题 [3.29](#). □

利用前述[命题 3.17](#) 对任意非多项式激活函数  $\sigma \in \mathcal{M}$  的推广, 得到[定理 3.9](#) 的如下推广.

**推论 3.18:** 设  $d, L \in \mathbb{N}$  且  $\sigma \in \mathcal{M}$ . 则  $\mathcal{N}_d^L(\sigma; L)$  是  $C^0(\mathbb{R}^d)$  的万能逼近族, 当且仅当  $\sigma$  不是多项式.

**证明:** 只证明 “ $\Leftarrow$ ” 方向; 另一方向仍留作习题 [3.25](#).

设  $\sigma \in \mathcal{M}$  不是多项式,  $K \subseteq \mathbb{R}^d$  为紧集, 且  $f \in C^0(\mathbb{R}^d)$ . 固定  $\varepsilon \in (0, 1)$ . 需要证明存在神经网络  $\Phi \in \mathcal{N}_d^1(\sigma; L)$ , 使得  $\sup_{\mathbf{x} \in K} |f(\mathbf{x}) - \Phi(\mathbf{x})| < \varepsilon$ . 当  $L = 1$  时结论由[定理 3.9](#) 成立, 故设  $L > 1$ .

由[定理 3.9](#), 存在  $\Phi_{\text{shallow}} \in \mathcal{N}_d^1(\sigma; 1)$ , 使得

$$\sup_{\mathbf{x} \in K} |f(\mathbf{x}) - \Phi_{\text{shallow}}(\mathbf{x})| < \frac{\varepsilon}{2}. \quad (3.8)$$

集合  $\{f(\mathbf{x}) \mid \mathbf{x} \in K\}$  的紧性说明, 可以找到  $n > 0$ , 使得

$$\{\Phi_{\text{shallow}}(\mathbf{x}) \mid \mathbf{x} \in K\} \subseteq [-n, n]. \quad (3.9)$$

取恒等映射的一个逼近  $\Phi_{\text{id}} \in \mathcal{N}_1^1(\sigma; L-1)$ , 使得

$$\sup_{x \in [-n, n]} |x - \Phi_{\text{id}}(x)| < \frac{\varepsilon}{2}, \quad (3.10)$$

这是由命题 3.17 对一般非多项式激活函数  $\sigma \in \mathcal{M}$  的推广保证的.

记  $\Phi := \Phi_{\text{id}} \circ \Phi_{\text{shallow}}$ . 根据命题 2.3 的第 4 项, 所需的  $\Phi \in \mathcal{N}_d^1(\sigma; L)$ . 此外, 式 (3.8)、(3.9) 和 (3.10) 蕴含

$$\begin{aligned} \sup_{\mathbf{x} \in K} |f(\mathbf{x}) - \Phi(\mathbf{x})| &= \sup_{\mathbf{x} \in K} |f(\mathbf{x}) - \Phi_{\text{id}}(\Phi_{\text{shallow}}(\mathbf{x}))| \\ &\leq \sup_{\mathbf{x} \in K} (|f(\mathbf{x}) - \Phi_{\text{shallow}}(\mathbf{x})| + |\Phi_{\text{shallow}}(\mathbf{x}) - \Phi_{\text{id}}(\Phi_{\text{shallow}}(\mathbf{x}))|) \\ &\leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon. \end{aligned}$$

证明完成. □

### 3.1.4 其他范数

除连续函数外, 还可对多种其他函数类和拓扑证明万能逼近定理, 从而也可能逼近具有不连续性或奇异性的函数. 下面仅举一例, 陈述紧集上 Lebesgue 空间的相应结果. 证明留作习题 3.28.

**推论 3.19:** 设  $d, L \in \mathbb{N}$ ,  $p \in [1, \infty)$ , 且  $\sigma \in \mathcal{M}$  不是多项式. 则对每个  $\varepsilon > 0$ 、每个紧集  $K \subseteq \mathbb{R}^d$  和每个  $f \in L^p(K)$ , 都存在  $\Phi^{f, \varepsilon} \in \mathcal{N}_d^1(\sigma; L)$ , 使得

$$\left( \int_K |f(\mathbf{x}) - \Phi(\mathbf{x})|^p d\mathbf{x} \right)^{1/p} \leq \varepsilon.$$

## 3.2 超表达激活函数与 Kolmogorov 叠加定理

上一节看到, 一大类激活函数都允许万能逼近. 然而, 这些结果没有说明为达到给定精度所必需的神经网络规模.

在后续章节进一步研究这一问题之前, 先介绍一个引人注目的结果, 说明激活函数的选择会显著影响所需网络规模. 它断言: 选取适当的激活函数后, 紧集  $K \subseteq \mathbb{R}^d$  上的每个  $f \in C^0(K)$  都能由规模为  $O(d^2)$  的神经网络逼近到任意所需精度  $\varepsilon > 0$ ; 特别地, 网络规模与  $\varepsilon > 0$ 、 $K$  和  $f$  均无关. 先讨论一维情形.

**命题 3.20:** 存在连续激活函数  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ , 使得对每个紧集  $K \subseteq \mathbb{R}$ 、每个  $\varepsilon > 0$  和每个  $f \in C^0(K)$ , 都存在  $\Phi(x) = \sigma(wx + b) \in \mathcal{N}_1^1(\sigma; 1, 1)$ , 使得

$$\sup_{x \in K} |f(x) - \Phi(x)| < \varepsilon.$$

**证明：** 以  $\tilde{\mathcal{P}}_n$  表示所有有理系数多项式  $p(x) = \sum_{j=0}^n q_j x^j$ ，即对所有  $j = 0, \dots, n$  都有  $q_j \in \mathbb{Q}$ . 集合  $\tilde{\mathcal{P}}_n$  可与  $n$  重 Cartesian 积  $\mathbb{Q} \times \dots \times \mathbb{Q}$  等同，因而可数. 所有有理系数多项式组成的集合  $\tilde{\mathcal{P}} := \bigcup_{n \in \mathbb{N}} \tilde{\mathcal{P}}_n$  也可数. 取这些多项式的一个枚举  $(p_i)_{i \in \mathbb{Z}}$ ，并令

$$\sigma(x) := \begin{cases} p_i(x - 2i) & \text{若 } x \in [2i, 2i + 1] \\ p_i(1)(2i + 2 - x) + p_{i+1}(0)(x - 2i - 1) & \text{若 } x \in (2i + 1, 2i + 2). \end{cases}$$

换言之， $\sigma$  在偶区间  $[2i, 2i + 1]$  上等于  $p_i$ ，在奇区间  $[2i + 1, 2i + 2]$  上为线性函数，故整体连续.

先设  $K = [0, 1]$ . 由例 3.6，对每个  $\varepsilon > 0$ ，存在

$$p(x) = \sum_{j=1}^n r_j x^j, \quad \sup_{x \in [0, 1]} |p(x) - f(x)| < \frac{\varepsilon}{2}.$$

选取充分接近  $r_j$  的  $q_j \in \mathbb{Q}$ ，使得  $\tilde{p}(x) := \sum_{j=1}^n q_j x^j$  满足  $\sup_{x \in [0, 1]} |\tilde{p}(x) - p(x)| < \varepsilon/2$ . 取  $i \in \mathbb{Z}$  使得  $\tilde{p}(x) = p_i(x)$ ，即对所有  $x \in [0, 1]$  都有  $p_i(x) = \sigma(2i + x)$ . 于是  $\sup_{x \in [0, 1]} |f(x) - \sigma(x + 2i)| < \varepsilon$ .

对一般紧集  $K$ ，设  $K \subseteq [a, b]$ . 由 Tietze 延拓定理， $f$  可连续延拓到  $[a, b]$ ，故不失一般性可设  $K = [a, b]$ . 由第一种情形，可找到  $i \in \mathbb{Z}$ ，使得令  $y = (x - a)/(b - a)$ （当  $x \in [a, b]$  时  $y \in [0, 1]$ ）后，

$$\sup_{x \in [a, b]} \left| f(x) - \sigma\left(\frac{x - a}{b - a} + 2i\right) \right| = \sup_{y \in [0, 1]} |f(y \cdot (b - a) + a) - \sigma(y + 2i)| < \varepsilon,$$

取  $w = 1/(b - a)$  和  $b = -a \cdot (b - a) + 2i$  即得结论.  $\square$

为把结果推广到任意维数，使用 Kolmogorov 叠加定理. 它说明每个  $d$  元连续函数都能表示成一些仅依赖一个变量的函数的复合.

**定理 3.21** (Kolmogorov): 对每个  $d \in \mathbb{N}$ ，存在  $2d^2 + d$  个单调递增函数  $\varphi_{i,j} \in C^0(\mathbb{R})$ ，其中  $i = 1, \dots, d, j = 1, \dots, 2d + 1$ ，使得对每个  $f \in C^0([0, 1]^d)$ ，都存在函数  $f_j \in C^0(\mathbb{R})$  ( $j = 1, \dots, 2d + 1$ ) 满足

$$f(\mathbf{x}) = \sum_{j=1}^{2d+1} f_j \left( \sum_{i=1}^d \varphi_{i,j}(x_i) \right) \quad \text{对所有 } \mathbf{x} \in [0, 1]^d.$$

Kolmogorov 定理由文献 [166] 证明. 为避开论证中技术性最强的部分，我们证明一个允许内层函数不连续的较简单命题. 尽管这绕开了一个关键困难，证明仍说明了为何可以把问题约化到一元函数.

**命题 3.22:** 对每个  $d \in \mathbb{N}$  和每个  $\varepsilon > 0$ ，存在  $d$  个单调递增函数  $h_j : [0, 1] \rightarrow \mathbb{R}$  ( $j = 1, \dots, d$ )，使得对每个  $L$ -Lipschitz 连续函数  $f : [0, 1]^d \rightarrow \mathbb{R}$ ，都存在  $g \in C^0(\mathbb{R})$  满足

$$\sup_{\mathbf{x} \in [0, 1]^d} \left| f(\mathbf{x}) - g\left(\sum_{j=1}^d h_j(x_j)\right) \right| \leq L \cdot \varepsilon. \quad (3.11)$$

**证明：** 设  $n \in \mathbb{N}$ , 并对  $i = 0, \dots, n$  令  $a_i = i/n$ . 对  $\boldsymbol{\nu} \in \Lambda_n := \{0, \dots, n-1\}^d$ , 令  $Q_{\boldsymbol{\nu}} := \times_{j=1}^d I_{\nu_j}$ , 其中当  $\nu_j + 1 < n$  时  $I_{\nu_j} = [a_{\nu_j}, a_{\nu_j+1})$ , 当  $\nu_j + 1 = n$  时  $I_{\nu_j} = [a_{\nu_j}, a_{\nu_j+1}]$ . 于是各  $Q_{\boldsymbol{\nu}}$  构成  $[0, 1]^d$  的不交分割. 再以  $f_{\boldsymbol{\nu}}$  表示  $f$  在立方体  $Q_{\boldsymbol{\nu}}$  中点处的值. 令

$$F_n(\mathbf{x}) := \sum_{\boldsymbol{\nu} \in \Lambda_n} f_{\boldsymbol{\nu}} \cdot \mathbb{1}_{Q_{\boldsymbol{\nu}}}(\mathbf{x}),$$

则

$$\sup_{\mathbf{x} \in [0, 1]^d} |f(\mathbf{x}) - F_n(\mathbf{x})| \leq L \frac{\sqrt{d}}{n}.$$

因为  $n$  任意, 要完成证明只需说明  $F_n(\mathbf{x})$  可写成  $g(\sum_{j=1}^d h_j(x_j))$ .

给每个  $\boldsymbol{\nu} \in \{0, \dots, n-1\}^d$  指派唯一的数

$$b_{\boldsymbol{\nu}} := \sum_{j=1}^d \nu_j \cdot n^{j-1}.$$

注意  $\{b_{\boldsymbol{\nu}} \mid \boldsymbol{\nu} \in \Lambda_n\} = \{0, \dots, n^d - 1\}$ . 对所有  $\boldsymbol{\nu} \in \Lambda_n$ , 定义依赖于  $f$  的函数  $g: \mathbb{R} \rightarrow \mathbb{R}$ :

$$g(x) := f_{\boldsymbol{\nu}} \quad \text{若 } x \in [b_{\boldsymbol{\nu}} - 1/4, b_{\boldsymbol{\nu}} + 1/4], \quad (3.12)$$

并把它连续延拓到整个  $\mathbb{R}$ . 对  $j = 1, \dots, d$ , 定义单调递增且与  $f$  无关的函数

$$h_j(x_j) := \begin{cases} 0 & \text{若 } x_j < 0 \\ n^{j-1} \cdot i & \text{若 } x_j \in I_i, \ 0 \leq i < n \\ n^j & \text{若 } x_j > 1. \end{cases}$$

则对任意  $\mathbf{x} \in Q_{\boldsymbol{\mu}}$ ,

$$h(\mathbf{x}) := \sum_{j=1}^d h_j(x_j) = \sum_{j=1}^d \mu_j \cdot n^{j-1} = b_{\boldsymbol{\mu}},$$

所以由式 (3.12),

$$g \circ h(\mathbf{x}) = g(b_{\boldsymbol{\mu}}) = f_{\boldsymbol{\mu}} = F_n(\mathbf{x}).$$

证明完成. □

**推论 3.23:** 设  $d \in \mathbb{N}$ . 取命题 3.20 中的激活函数  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 则对每个紧集  $K \subseteq \mathbb{R}^d$ , 每个  $\varepsilon > 0$  和每个  $f \in C^0(K)$ , 都存在  $\Phi \in \mathcal{N}_d^1(\sigma; 2, 2d^2 + d)$  (即  $\text{width}(\Phi) = 2d^2 + d$  且  $\text{depth}(\Phi) = 2$ ), 使得

$$\sup_{\mathbf{x} \in K} |f(\mathbf{x}) - \Phi(\mathbf{x})| < \varepsilon.$$

**证明：** 不失一般性，可设  $K = [0, 1]^d$ ；一般情形由 Tietze 延拓定理以及[命题 3.20](#) 证明中的缩放论证得到。

取[定理 3.21](#) 中的  $f_j, \varphi_{i,j}$ ，其中  $i = 1, \dots, d, j = 1, \dots, 2d+1$ 。固定  $\varepsilon > 0$ ，取足够大的  $a > 0$ ，使得

$$\sup_{i,j} \sup_{x \in [0,1]} |\varphi_{i,j}(x)| \leq a.$$

由于每个  $f_j$  在紧集  $[-da, da]$  上一致连续，可找到  $\delta > 0$ ，使得

$$\sup_j \sup_{\substack{|y-\tilde{y}| < \delta \\ |y|, |\tilde{y}| \leq da}} |f_j(y) - f_j(\tilde{y})| < \frac{\varepsilon}{2(2d+1)}. \quad (3.13)$$

由[命题 3.20](#)，存在  $w_{i,j}, b_{i,j} \in \mathbb{R}$ ，使得

$$\sup_{i,j} \sup_{x \in [0,1]} |\varphi_{i,j}(x) - \underbrace{\sigma(w_{i,j}x + b_{i,j})}_{=:\tilde{\varphi}_{i,j}(x)}| < \frac{\delta}{d} \quad (3.14)$$

并存在  $w_j, b_j \in \mathbb{R}$ ，使得

$$\sup_j \sup_{|y| \leq a+\delta} |f_j(y) - \underbrace{\sigma(w_j y + b_j)}_{=:\tilde{f}_j(y)}| < \frac{\varepsilon}{2(2d+1)}. \quad (3.15)$$

于是由式 (3.14)，对所有  $\mathbf{x} \in [0, 1]^d$ ，

$$\left| \sum_{i=1}^d \varphi_{i,j}(x_i) - \sum_{i=1}^d \tilde{\varphi}_{i,j}(x_i) \right| < d \frac{\delta}{d} = \delta.$$

令

$$y_j := \sum_{i=1}^d \varphi_{i,j}(x_i), \quad \tilde{y}_j := \sum_{i=1}^d \tilde{\varphi}_{i,j}(x_i)$$

则  $|y_j - \tilde{y}_j| < \delta$ 。利用式 (3.13) 和 (3.15)，得到

$$\begin{aligned} \left| f(\mathbf{x}) - \sum_{j=1}^{2d+1} \sigma \left( w_j \cdot \left( \sum_{i=1}^d \sigma(w_{i,j}x_i + b_{i,j}) \right) + b_j \right) \right| &= \left| \sum_{j=1}^{2d+1} (f_j(y_j) - \tilde{f}_j(\tilde{y}_j)) \right| \\ &\leq \sum_{j=1}^{2d+1} (|f_j(y_j) - f_j(\tilde{y}_j)| + |f_j(\tilde{y}_j) - \tilde{f}_j(\tilde{y}_j)|) \\ &\leq \sum_{j=1}^{2d+1} \left( \frac{\varepsilon}{2(2d+1)} + \frac{\varepsilon}{2(2d+1)} \right) \leq \varepsilon. \end{aligned}$$

证明完成. □

Kolmogorov 叠加定理颇为有趣，因为它说明通过复合可把  $d$  维函数的逼近约化到通常简单得多的一维情形。神经网络天然适合逼近具有复合结构的函数。不过，正如命题 3.22 的证明所示，当  $d$  很大时，定理 3.21 中的函数  $f_j$  虽然只有一维，自身却可能非常复杂且难以逼近。

与这一构造密切相关，命题 3.20 中的“魔法”激活函数编码了单位区间上所有有理系数多项式的信息，因此规模为  $O(1)$  的神经网络就足以把每个函数逼近到任意精度。自然地，没有实际算法能够高效确定这一架构的适当权重和偏置。因此，第 3.2 节的结果应谨慎看待，其实际意义十分有限。尽管如此，它们强调：万能逼近虽是神经网络的一项基本而重要的性质，却仍留下许多未探索的问题。为进一步理解实际相关的架构，后续章节将研究采用 ReLU 等激活函数的神经网络。

## 参考文献与延伸阅读

万能逼近定理的基础可追溯到 20 世纪 80 年代末 Cybenko [72]、Hornik 等 [136, 135]、Funahashi [97] 以及 Carroll 与 Dickinson [56] 的奠基工作。后来这些结果被推广到更广泛的激活函数和架构。第 3.1 节的分析紧随文献 [180] 的论证；该文实质上说明，只要激活函数不是多项式，就能实现万能逼近。引理 3.11 的证明取自文献 [187, Theorem 2.1]，更早的同类结果见文献 [319]。

定理 3.21 中的 Kolmogorov 叠加定理最初于 1957 年证明 [166]；较新的构造性证明例如见文献 [46]。Kolmogorov 定理及其与神经网络的明显联系启发了该领域的多项研究 [220, 171, 205, 276, 145]，其实际意义则仍有争论 [104, 170]。第 3.2 节“魔法”激活函数的想法来自文献 [193]；该文说明这种激活函数甚至可以选成单调递增的。



## 习题

- 3.24.** 写出  $C^0(\mathbb{R}^d)$  上一个 (最小) 拓扑的生成族, 使得  $f_n \rightarrow f \in C^0(\mathbb{R}^d)$  当且仅当  $f_n \xrightarrow{\text{cc}} f$ , 并证明这一等价性. 该拓扑称为紧收敛拓扑.
- 3.25.** 证明定理 3.9 和推论 3.18 中的 “ $\Rightarrow$ ” 方向.
- 3.26.** 证明引理 3.13. 提示: 对充分大的  $n \in \mathbb{N}$ , 考虑  $\sigma(nx)$ .
- 3.27.** 设  $k \in \mathbb{N}$ ,  $\sigma \in \mathcal{M}$ , 并假设对所有  $\varphi \in C_c^\infty(\mathbb{R})$  都有  $\sigma * \varphi \in \mathcal{P}_k$ . 证明  $\sigma \in \mathcal{P}_k$ .  
提示: 取  $\psi \in C_c^\infty(\mathbb{R})$ , 使得  $\psi \geq 0$  且  $\int_{\mathbb{R}} \psi(x) dx = 1$ , 并令  $\psi_\varepsilon(x) := \psi(x/\varepsilon)/\varepsilon$ . 利用在  $\sigma$  的不连续点之外, 当  $\varepsilon \rightarrow 0$  时有  $\psi_\varepsilon * \sigma(x) \rightarrow \sigma(x)$ . 推出  $\sigma$  分段属于  $\mathcal{P}_k$ , 最后证明  $\sigma \in C^k(\mathbb{R})$ .
- 3.28.** 利用推论 3.18 证明推论 3.19.
- 3.29.** 补全  $L > 1$  时命题 3.17 的证明.

# 样条

在第 3 章中，我们看到，充分大的神经网络能够以任意精度逼近每个连续函数。然而，这些结果并未进一步说明“充分大”究竟意味着什么，也未说明怎样的架构才算合适。理想情况下，给定函数  $f$  和所需精度  $\varepsilon > 0$ ，我们希望得到所需规模、深度与宽度的一个（可能是尖锐的）界，从而保证存在误差不超过  $\varepsilon$  的神经网络逼近。

逼近论研究函数  $f$  的性质（例如光滑性）、逼近精度与达到该精度所需参数数量之间的权衡。例如，给定  $k, d \in \mathbb{N}$ ，要以一致误差  $\varepsilon$  逼近满足  $\|f\|_{C^k([0,1]^d)} \leq 1$  的函数  $f: [0,1]^d \rightarrow \mathbb{R}$ ，需要多少个参数？众所周知，样条可以用  $O(\varepsilon^{-d/k})$  个简单的（分段多项式）基函数的叠加达到这一逼近精度。本章遵循文献 [200]，说明某些高阶 S 形神经网络在网络规模方面能够达到相同性能。事实上，从逼近论的观点看，我们将说明所考虑的神经网络至少与样条叠加同样富有表达力。

## 4.1 B 样条与光滑函数

下面引入一种简单的样条及其逼近性质。

**定义 4.1:** 对  $n \in \mathbb{N}$ ，定义  $n$  阶一元基数 B 样条 (univariate cardinal B-spline) 为

$$S_n(x) := \frac{1}{(n-1)!} \sum_{\ell=0}^n (-1)^\ell \binom{n}{\ell} \sigma_{\text{ReLU}}(x - \ell)^{n-1} \quad \text{对所有 } x \in \mathbb{R}, \quad (4.1)$$

其中  $0^0 := 0$ ，而  $\sigma_{\text{ReLU}}$  表示 ReLU 激活函数。

对基数 B 样条作平移和伸缩，即得到一元样条系统。对这些一元样条取张量积，则得到称为多元 B 样条的一组高维函数。

**定义 4.2:** 对  $t \in \mathbb{R}$  及  $n, \ell \in \mathbb{N}$ ，定义  $S_{\ell,t,n} := S_n(2^\ell(\cdot - t))$ 。此外，对  $d \in \mathbb{N}$ 、 $\mathbf{t} \in \mathbb{R}^d$  及  $n, \ell \in \mathbb{N}$ ，定义多元 B 样条 (multivariate B-spline)  $S_{\ell,\mathbf{t},n}^d$  为

$$S_{\ell,\mathbf{t},n}^d(\mathbf{x}) := \prod_{i=1}^d S_{\ell,t_i,n}(x_i) \quad \text{对所有 } \mathbf{x} = (x_1, \dots, x_d) \in \mathbb{R}^d,$$

并令

$$\mathcal{B}^n := \{S_{\ell,\mathbf{t},n}^d \mid \ell \in \mathbb{N}, \mathbf{t} \in \mathbb{R}^d\},$$

称其为  $n$  阶 B 样条字典。

引入系统  $\mathcal{B}^n$  后，我们希望了解用  $\mathcal{B}^n$  中元素的叠加能够多好地表示每个光滑函数。下述定理改写自更一般的结果 [230, Theorem 7]；与此处表述更接近的版本另见文献 [195, Theorem D.3]。

**定理 4.3:** 设  $d, n, k \in \mathbb{N}$  且  $0 < k \leq n$ . 则存在常数  $C$ , 使得对每个  $f \in C^k([0, 1]^d)$  和每个  $N \in \mathbb{N}$ , 都存在  $c_i \in \mathbb{R}$  与  $B_i \in \mathcal{B}^n$  ( $i = 1, \dots, N$ ), 其中  $|c_i| \leq C\|f\|_{L^\infty([0, 1]^d)}$ , 并且

$$\left\| f - \sum_{i=1}^N c_i B_i \right\|_{L^\infty([0, 1]^d)} \leq C N^{-k/d} \|f\|_{C^k([0, 1]^d)}.$$

**注 4.4:** 定理 4.3 中有若干关键概念将在全书反复出现. 参数数量  $N$  决定逼近精度  $N^{-k/d}$ . 这意味着, 要达到精度  $\varepsilon > 0$ , 按此上界需要  $O(\varepsilon^{-d/k})$  个参数; 该数量随  $d$  指数增长. 对  $d$  的这种指数依赖称为维数灾难, 后续各章还将讨论它. 光滑性参数  $k$  的作用与  $d$  相反, 它会改善收敛速率. 因而, 较光滑的函数比粗糙函数可用更少的 B 样条逼近. 这种更高效的逼近要求使用阶数  $n \geq k$  的 B 样条. 下文将看到, B 样条的阶数与神经网络的深度概念密切相关.  $\diamond$

## 4.2 用高阶 S 形激活函数重新逼近 B 样条

现在说明如何把 B 样条的逼近速率转移到某些神经网络上. 以下论证基于文献 [198].

**定义 4.5:** 若函数  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  属于  $C^{q-1}(\mathbb{R})$ , 且存在  $C > 0$  使得

$$\begin{aligned} \frac{\sigma(x)}{x^q} &\rightarrow 0 && \text{当 } x \rightarrow -\infty, \\ \frac{\sigma(x)}{x^q} &\rightarrow 1 && \text{当 } x \rightarrow \infty, \\ |\sigma(x)| &\leq C(1 + |x|)^q && \text{对所有 } x \in \mathbb{R}, \end{aligned}$$

则称  $\sigma$  是  $q \in \mathbb{N}$  阶 S 形函数.

**例 4.6:** 修正幂单元  $x \mapsto \sigma_{\text{ReLU}}(x)^q$  是  $q$  阶 S 形函数.  $\diamond$

以下目标是说明, 神经网络可以用与  $N$  成正比的参数数量逼近  $N$  个 B 样条的线性组合. 作为定理 4.3 的直接推论, 我们由此得到神经网络的一个收敛速率. 先用固定规模的神经网络逼近单个一元 B 样条.

**命题 4.7:** 设  $n \in \mathbb{N}$ ,  $n \geq 2$ ,  $K > 0$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是阶数  $q \geq 2$  的 S 形函数. 则存在常数  $C > 0$ , 使得对每个  $\varepsilon > 0$ , 都存在以  $\sigma$  为激活函数、具有  $\lceil \log_q(n-1) \rceil$  层且规模为  $C$  的神经网络  $\Phi^{S_n}$ , 满足

$$\|S_n - \Phi^{S_n}\|_{L^\infty([-K, K])} \leq \varepsilon.$$

**证明:** 由定义 (4.1),  $S_n$  是  $\sigma_{\text{ReLU}}^{n-1}$  的  $n+1$  个平移的线性组合. 先逼近  $\sigma_{\text{ReLU}}^{n-1}$ . 不难看出 (习题 4.10), 对每个  $K' > 0$  和每个  $t \in \mathbb{N}$ , 都有

$$\left| a^{-q^t} \underbrace{\sigma \circ \sigma \circ \dots \circ \sigma}_{t \text{ 次}}(ax) - \sigma_{\text{ReLU}}(x)^{q^t} \right| \rightarrow 0 \quad \text{当 } a \rightarrow \infty, \quad (4.2)$$

且收敛关于所有  $x \in [-K', K']$  一致成立.

令  $t := \lceil \log_q(n-1) \rceil$ . 因为  $n \geq 2$ , 所以  $t \geq 1$ , 且  $q^t \geq n-1$ . 因而, 对每个  $K' > 0$  和  $\varepsilon > 0$ , 存在具有  $\lceil \log_q(n-1) \rceil$  层的神经网络  $\Phi_\varepsilon^{q^t}$ , 满足

$$|\Phi_\varepsilon^{q^t}(x) - \sigma_{\text{ReLU}}(x)^{q^t}| \leq \varepsilon \quad \text{对所有 } x \in [-K', K']. \quad (4.3)$$

这说明我们能够逼近  $q^t \geq n-1$  次幂的 ReLU. 然而, 目标是逼近  $n-1$  次幂的 ReLU, 而  $n-1$  可能小于  $q^t$ . 为降低次数, 我们模拟  $\Phi_\varepsilon^{q^t}$  的近似导数. 具体地, 证明如下断言: 对所有  $1 \leq p \leq q^t$ 、每个  $K' > 0$  和每个  $\varepsilon > 0$ , 都存在具有  $\lceil \log_q(n-1) \rceil$  层的神经网络  $\Phi_\varepsilon^p$ , 满足

$$|\Phi_\varepsilon^p(x) - \sigma_{\text{ReLU}}(x)^p| \leq \varepsilon \quad \text{对所有 } x \in [-K', K']. \quad (4.4)$$

当  $p = q^t$  时该断言成立. 现在按  $p = q^t, q^t - 1, \dots$  作归纳. 假设 (4.4) 对某个  $p \in \{2, \dots, q^t\}$  成立, 并固定  $\delta \geq 0$ . 则

$$\begin{aligned} & \left| \frac{\Phi_{\delta^2}^p(x + \delta) - \Phi_{\delta^2}^p(x)}{p\delta} - \sigma_{\text{ReLU}}(x)^{p-1} \right| \\ & \leq \frac{2\delta}{p} + \left| \frac{\sigma_{\text{ReLU}}(x + \delta)^p - \sigma_{\text{ReLU}}(x)^p}{p\delta} - \sigma_{\text{ReLU}}(x)^{p-1} \right|. \end{aligned}$$

因此, 由二项式定理, 存在  $\delta_* > 0$ , 使得对所有  $x \in [-K', K']$ ,

$$\left| \frac{\Phi_{\delta_*^2}^p(x + \delta_*) - \Phi_{\delta_*^2}^p(x)}{p\delta_*} - \sigma_{\text{ReLU}}(x)^{p-1} \right| \leq \varepsilon.$$

由命题 2.3,  $(\Phi_{\delta_*^2}^p(x + \delta_*) - \Phi_{\delta_*^2}^p(x))/(p\delta_*)$  是一个具有  $\lceil \log_q(n-1) \rceil$  层且规模与  $\varepsilon$  无关的神经网络. 将该神经网络记为  $\Phi_\varepsilon^{p-1}$ , 便说明 (4.4) 对  $p-1$  成立, 从而完成归纳并证明断言.

对每个神经网络  $\Phi$ , 每个空间平移  $\Phi(\cdot - t)$  都是具有相同架构的神经网络. 因而, 和式 (4.1) 中的每一项都能以任意精度由固定规模的神经网络逼近. 再由命题 2.3, 相同深度的神经网络之和仍是相同深度的神经网络, 结论得证.  $\square$

下面把命题 4.7 推广到任意  $\ell, d \in \mathbb{N}$ 、 $\mathbf{t} \in \mathbb{R}^d$  的多元样条  $S_{\ell, \mathbf{t}, n}^d$ .

**命题 4.8:** 设  $n, d \in \mathbb{N}$ 、 $n \geq 2$ 、 $K > 0$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是阶数  $q \geq 2$  的 S 形函数. 再设  $\ell \in \mathbb{N}$  且  $\mathbf{t} \in \mathbb{R}^d$ . 则存在常数  $C > 0$ , 使得对每个  $\varepsilon > 0$ , 都存在以  $\sigma$  为激活函数、具有  $\lceil \log_2(d) \rceil + \lceil \log_q(n-1) \rceil$  层且规模为  $C$  的神经网络  $\Phi^{S_{\ell, \mathbf{t}, n}^d}$ , 满足

$$\|S_{\ell, \mathbf{t}, n}^d - \Phi^{S_{\ell, \mathbf{t}, n}^d}\|_{L^\infty([-K, K]^d)} \leq \varepsilon.$$

**证明:** 由定义,

$$S_{\ell, \mathbf{t}, n}^d(\mathbf{x}) = \prod_{i=1}^d S_{\ell, t_i, n}(x_i), \quad S_{\ell, t_i, n}(x_i) = S_n(2^\ell(x_i - t_i)).$$

由命题 4.7, 存在常数  $C' > 0$ , 使得对每个  $i = 1, \dots, d$  和所有  $\varepsilon > 0$ , 都存在规模为  $C'$ 、具有  $\lceil \log_q(n-1) \rceil$  层的神经网络  $\Phi^{S_{\ell, t_i, n}}$ , 满足

$$\|S_{\ell, t_i, n} - \Phi^{S_{\ell, t_i, n}}\|_{L^\infty([-K, K]^d)} \leq \varepsilon.$$

当  $d = 1$  时, 这已证明结论. 对一般的  $d$ , 还需说明可以逼近  $i = 1, \dots, d$  时各  $\Phi^{S_{\ell, t_i, n}}$  的乘积.

先用归纳法证明如下断言: 对每个  $d \in \mathbb{N}$ 、 $d \geq 2$ , 存在常数  $C'' > 0$ , 使得对所有  $K' \geq 1$  和所有  $\varepsilon > 0$ , 都存在规模为  $C''$ 、具有  $\lceil \log_2(d) \rceil$  层且激活函数为  $\sigma$  的神经网络  $\Phi_{\text{mult}, \varepsilon, d}$ , 并且对满足  $|x_i| \leq K'$  ( $i = 1, \dots, d$ ) 的所有  $x_1, \dots, x_d$ ,

$$\left| \Phi_{\text{mult}, \varepsilon, d}(x_1, \dots, x_d) - \prod_{i=1}^d x_i \right| < \varepsilon. \quad (4.5)$$

对归纳基, 令  $d = 2$ . 与命题 4.7 的证明类似, 可以说明存在  $C''' > 0$ , 使得对每个  $\varepsilon > 0$  和  $K' > 0$ , 都存在规模为  $C'''$ 、具有一个隐藏层的神经网络  $\Phi_{\text{square}, \varepsilon}$ , 满足

$$|\Phi_{\text{square}, \varepsilon} - \sigma_{\text{ReLU}}(x)^2| \leq \varepsilon \quad \text{对所有 } |x| \leq K'.$$

对每个  $x = (x_1, x_2) \in \mathbb{R}^2$ ,

$$\begin{aligned} x_1 x_2 &= \frac{1}{2} ((x_1 + x_2)^2 - x_1^2 - x_2^2) \\ &= \frac{1}{2} (\sigma_{\text{ReLU}}(x_1 + x_2)^2 + \sigma_{\text{ReLU}}(-x_1 - x_2)^2 - \sigma_{\text{ReLU}}(x_1)^2 \\ &\quad - \sigma_{\text{ReLU}}(-x_1)^2 - \sigma_{\text{ReLU}}(x_2)^2 - \sigma_{\text{ReLU}}(-x_2)^2). \end{aligned} \quad (4.6)$$

右端每一项都能由规模为  $C'''$ 、具有一个隐藏层的神经网络以一致误差  $\varepsilon/6$  逼近. 由命题 2.3, 存在满足  $d = 2$  时 (4.5) 的神经网络  $\Phi_{\text{mult}, \varepsilon, 2}$ .

假设 (4.5) 对  $d-1 \geq 1$  成立, 并令  $\varepsilon > 0$ 、 $K' \geq 1$ . 有

$$\prod_{i=1}^d x_i = \prod_{i=1}^{\lfloor d/2 \rfloor} x_i \cdot \prod_{i=\lfloor d/2 \rfloor + 1}^d x_i. \quad (4.7)$$

现在利用归纳假设, 用神经网络逼近 (4.7) 右端乘积中的两项.

为简单起见, 先假设  $\lceil \log_2(\lfloor d/2 \rfloor) \rceil = \lceil \log_2(d - \lfloor d/2 \rfloor) \rceil$ . 一般情形可由命题 3.17 处理. 由归纳假设, 存在均具有  $\lceil \log_2(\lfloor d/2 \rfloor) \rceil$  层的神经网络  $\Phi_{\text{mult}, 1}$  与  $\Phi_{\text{mult}, 2}$ , 使得对所有满足  $|x_i| \leq K'$  ( $i = 1, \dots, d$ ) 的  $x_i$ ,

$$\begin{aligned} \left| \Phi_{\text{mult}, 1}(x_1, \dots, x_{\lfloor d/2 \rfloor}) - \prod_{i=1}^{\lfloor d/2 \rfloor} x_i \right| &< \frac{\varepsilon}{4((K')^{\lfloor d/2 \rfloor} + \varepsilon)}, \\ \left| \Phi_{\text{mult}, 2}(x_{\lfloor d/2 \rfloor + 1}, \dots, x_d) - \prod_{i=\lfloor d/2 \rfloor + 1}^d x_i \right| &< \frac{\varepsilon}{4((K')^{\lfloor d/2 \rfloor} + \varepsilon)}. \end{aligned}$$

由命题 2.3,

$$\Phi_{\text{mult},\varepsilon,d} := \Phi_{\text{mult},\varepsilon/2,2} \circ (\Phi_{\text{mult},1}, \Phi_{\text{mult},2})$$

是具有  $1 + \lceil \log_2(\lfloor d/2 \rfloor) \rceil = \lceil \log_2(d) \rceil$  层的神经网络. 按构造,  $\Phi_{\text{mult},\varepsilon,d}$  的规模不依赖于  $K'$  或  $\varepsilon$ . 因此, 为完成归纳, 只需证明 (4.5).

对所有  $a, b, c, d \in \mathbb{R}$ , 有

$$|ab - cd| \leq |a| |b - d| + |d| |a - c|.$$

因而, 对所有满足  $|x_i| \leq K'$  ( $i = 1, \dots, d$ ) 的  $x_1, \dots, x_d$ , 有

$$\begin{aligned} & \left| \prod_{i=1}^d x_i - \Phi_{\text{mult},\varepsilon,d}(x_1, \dots, x_d) \right| \\ & \leq \frac{\varepsilon}{2} + \left| \prod_{i=1}^{\lfloor d/2 \rfloor} x_i \prod_{i=\lfloor d/2 \rfloor+1}^d x_i - \Phi_{\text{mult},1}(x_1, \dots, x_{\lfloor d/2 \rfloor}) \Phi_{\text{mult},2}(x_{\lfloor d/2 \rfloor+1}, \dots, x_d) \right| \\ & \leq \frac{\varepsilon}{2} + (K')^{\lfloor d/2 \rfloor} \frac{\varepsilon}{4((K')^{\lfloor d/2 \rfloor} + \varepsilon)} + ((K')^{\lfloor d/2 \rfloor} + \varepsilon) \frac{\varepsilon}{4((K')^{\lfloor d/2 \rfloor} + \varepsilon)} < \varepsilon. \end{aligned}$$

这便完成了 (4.5) 的证明.

最后, 应用命题 2.3, 将乘法网络与由  $i = 1, \dots, d$  时各  $\Phi^{S_{\ell,t_i,n}}$  组成的神经网络复合, 即得总体结论. 由于上述每一步中各网络的规模都不依赖于逼近精度, 最终网络也具有这一性质.  $\square$

命题 4.8 说明, 单个多元 B 样条可由规模与精度无关的神经网络逼近. 将这一观察与定理 4.3 结合, 得到下述结果.

**定理 4.9:** 设  $d, n, k \in \mathbb{N}$ , 其中  $0 < k \leq n$  且  $n \geq 2$ . 设  $q \geq 2$ , 并设  $\sigma$  为  $q$  阶 S 形函数. 则存在常数  $C$ , 使得对每个  $f \in C^k([0, 1]^d)$  和每个  $N \in \mathbb{N}$ , 都存在以  $\sigma$  为激活函数、具有  $\lceil \log_2(d) \rceil + \lceil \log_q(k-1) \rceil$  层且规模不超过  $CN$  的神经网络  $\Phi^N$ , 满足

$$\|f - \Phi^N\|_{L^\infty([0,1]^d)} \leq CN^{-k/d} \|f\|_{C^k([0,1]^d)}.$$

**证明:** 固定  $N \in \mathbb{N}$ . 由定理 4.3, 存在系数  $|c_i| \leq C\|f\|_{L^\infty([0,1]^d)}$  及  $B_i \in \mathcal{B}^n$  ( $i = 1, \dots, N$ ), 使得

$$\left\| f - \sum_{i=1}^N c_i B_i \right\|_{L^\infty([0,1]^d)} \leq CN^{-k/d} \|f\|_{C^k([0,1]^d)}.$$

此外, 由命题 4.8, 对每个  $i = 1, \dots, N$ , 都存在具有  $\lceil \log_2(d) \rceil + \lceil \log_q(k-1) \rceil$  层且规模固定的神经网络  $\Phi^{B_i}$ , 它在  $[-1, 1]^d \supseteq [0, 1]^d$  上以误差  $\varepsilon := N^{-k/d}/N$  逼近  $B_i$ .  $\Phi^{B_i}$  的规模与  $i$  和  $N$  均无关.

由命题 2.3, 存在神经网络  $\Phi^N$ , 它在  $[0, 1]^d$  上以一致误差  $\varepsilon$  逼近  $\sum_{i=1}^N c_i B_i$ , 并具有  $\lceil \log_2(d) \rceil + \lceil \log_q(k-1) \rceil$  层. 该网络的规模关于  $N$  线性增长 (见习题 4.11). 证明完毕.  $\square$

定理 4.9 说明, 采用高阶 S 形函数的神经网络能够以与样条逼近相同的精度逼近光滑函数, 同时具有可比的参数数量. 就光滑性参数  $k$  而言, 所需网络深度按  $O(\log k)$  增长; 比较注 4.4.

## 文献与延伸阅读

把 S 形激活函数与基于样条的逼近联系起来的论证最早见于文献 [200, 198]. 关于样条逼近的更多细节, 参见文献 [230] 或专著 [279].

先用神经网络逼近基函数、再提升这些基函数已有逼近结果的一般策略已在文献中得到广泛应用, 本书后文也会再次出现. 后续各章主要关注 ReLU 激活函数; 这里列举几种遵循上述策略、采用非 ReLU 激活函数的重要方法: 为逼近解析函数, 文献 [199] 模拟单项式基; 为逼近周期函数, 文献 [201] 重建三角多项式基; 文献 [233] 模拟小波基. 此外, 研究者还通过脊波 [53] 和脊函数 [144] 表示系统研究神经网络. 文献 [38] 给出了描述如何模拟表示系统以转移逼近结果的一般框架.



## 习题

- 4.10. 证明 (4.2) 成立.
- 4.11. 设  $L \in \mathbb{N}$ 、 $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ , 并设  $\Phi_1, \Phi_2$  是架构分别为  $(\sigma; d_0, d_1^{(1)}, \dots, d_L^{(1)}, d_{L+1})$  与  $(\sigma; d_0, d_1^{(2)}, \dots, d_L^{(2)}, d_{L+1})$  的两个神经网络. 证明  $\Phi_1 + \Phi_2$  是神经网络, 且  $\text{size}(\Phi_1 + \Phi_2) \leq \text{size}(\Phi_1) + \text{size}(\Phi_2)$ .
- 4.12. 证明: 当  $\sigma = \sigma_{\text{ReLU}}^2$  且  $k \leq 2$  时, 对所有  $f \in C^k([0, 1]^d)$ , 定理 4.9 中逼近神经网络的全部权重的绝对值都可由  $O(\max\{2, \|f\|_{C^k([0, 1]^d)}\})$  控制.

# ReLU 神经网络

本章讨论采用第 2.3 节所引入 ReLU 激活函数  $\sigma_{\text{ReLU}}$  的前馈神经网络，并称之为 ReLU 神经网络。由于形式简单且能缓解梯度消失与梯度爆炸现象，ReLU 是实践中使用最广泛的激活函数之一。

前几章证明的一个关键步骤是逼近激活函数的导数，以模拟多项式。ReLU 是分段线性的，因而不能使用这一技巧；这使其分析与较光滑激活函数的情形有根本差异。尽管如此，我们将看到，即使如此简单的激活函数也会产生极其丰富、具有卓越逼近能力的函数类。

为形式化这些结果，本章首先采用文献 [236] 的框架，以便在神经网络相加、复合等基本操作中追踪网络参数数量，从而在用简单网络构造更复杂网络时控制网络复杂度。做好这些准备后，本章其余部分研究 ReLU 神经网络与连续分段线性函数类之间的联系。第 5.2 节将说明每个这类函数都能由 ReLU 神经网络精确表示；第 5.3 节进一步分析所需网络复杂度；最后，第 5.4 节给出 ReLU 神经网络的第一个逼近定理。其思路与第 4 章相似：把分段线性函数的既有逼近理论转移到某种架构的 ReLU 神经网络类。

## 5.1 ReLU 基本演算

本节形式化 ReLU 神经网络的组合与操作方式。命题 2.3 已经给出这类结果的一个实例；现在在激活函数为 ReLU 的假设下进一步精化它，并加入所得神经网络权重数量的界。以下四种操作是后续全部构造的基础。

- 复现恒等映射：命题 3.17 说明，对大多数激活函数，神经网络可以构造恒等映射的一个逼近。对 ReLU 可以得到更强的结果，即精确复现恒等映射。这一恒等网络对于把给定网络延拓为更深网络以及高效实现复合操作至关重要。
- 复合：命题 2.3 说明两个神经网络的复合仍是神经网络，但未研究所得网络的规模。对 ReLU 激活函数，可以非常高效地完成复合；所得网络的权重数量至多为原来两个网络权重总数的常数倍。
- 并行化：命题 2.3 也讨论了两个神经网络的并行化。我们将精化这一概念并明确所得网络的规模。
- 线性组合：类似地，我们将给出两个神经网络之和的精确规模界。

### 5.1.1 恒等映射

先把  $\mathbb{R}^d$  上的恒等映射表示成深度为  $L \in \mathbb{N}$  的神经网络。

**引理 5.1** (恒等映射): 设  $L \in \mathbb{N}$ . 则存在 ReLU 神经网络  $\Phi_L^{\text{id}}$ , 使得对所有  $\mathbf{x} \in \mathbb{R}^d$  都有  $\Phi_L^{\text{id}}(\mathbf{x}) = \mathbf{x}$ . 此外,

$$\text{depth}(\Phi_L^{\text{id}}) = L, \quad \text{width}(\Phi_L^{\text{id}}) = 2d, \quad \text{size}(\Phi_L^{\text{id}}) = 2d(L+1).$$

**证明:** 以  $\mathbf{I}_d \in \mathbb{R}^{d \times d}$  表示单位矩阵, 选取权重

$$\begin{aligned} & (\mathbf{W}^{(0)}, \mathbf{b}^{(0)}), \dots, (\mathbf{W}^{(L)}, \mathbf{b}^{(L)}) \\ & := \left( \begin{pmatrix} \mathbf{I}_d \\ -\mathbf{I}_d \end{pmatrix}, \mathbf{0} \right), \underbrace{(\mathbf{I}_{2d}, \mathbf{0}), \dots, (\mathbf{I}_{2d}, \mathbf{0})}_{L-1 \text{ 次}}, ((\mathbf{I}_d, -\mathbf{I}_d), \mathbf{0}). \end{aligned}$$

对所有  $x \in \mathbb{R}$ , 有  $x = \sigma_{\text{ReLU}}(x) - \sigma_{\text{ReLU}}(-x)$ ; 对所有  $x \geq 0$ , 有  $\sigma_{\text{ReLU}}(x) = x$ . 因而, 与上述权重相对应的神经网络  $\Phi_L^{\text{id}}$  显然满足引理断言.  $\square$

习题 5.24 将说明, S 形激活函数不具有精确表示恒等映射的性质; 多项式激活函数则具有这一性质, 另见命题 3.17.

### 5.1.2 复合

设两个神经网络  $\Phi_1, \Phi_2$  的架构分别为  $(\sigma_{\text{ReLU}}; d_0^1, \dots, d_{L_1+1}^1)$  和  $(\sigma_{\text{ReLU}}; d_0^2, \dots, d_{L_2+1}^2)$ , 权重与偏置分别为

$$\begin{aligned} & (\mathbf{W}_1^{(0)}, \mathbf{b}_1^{(0)}), \dots, (\mathbf{W}_1^{(L_1)}, \mathbf{b}_1^{(L_1)}), \\ & (\mathbf{W}_2^{(0)}, \mathbf{b}_2^{(0)}), \dots, (\mathbf{W}_2^{(L_2)}, \mathbf{b}_2^{(L_2)}). \end{aligned}$$

若  $\Phi_1$  的输出维数  $d_{L_1+1}^1$  等于  $\Phi_2$  的输入维数  $d_0^2$ , 则可定义两种连接. 第一种,  $\Phi_2 \circ \Phi_1$  是具有如下权重与偏置的神经网络:

$$\begin{aligned} & (\mathbf{W}_1^{(0)}, \mathbf{b}_1^{(0)}), \dots, (\mathbf{W}_1^{(L_1-1)}, \mathbf{b}_1^{(L_1-1)}), (\mathbf{W}_2^{(0)} \mathbf{W}_1^{(L_1)}, \mathbf{W}_2^{(0)} \mathbf{b}_1^{(L_1)} + \mathbf{b}_2^{(0)}), \\ & (\mathbf{W}_2^{(1)}, \mathbf{b}_2^{(1)}), \dots, (\mathbf{W}_2^{(L_2)}, \mathbf{b}_2^{(L_2)}). \end{aligned}$$

第二种, 定义  $\Phi_2 \bullet \Phi_1 := \Phi_2 \circ \Phi_1^{\text{id}} \circ \Phi_1$ . 用权重与偏置表示, 即

$$\begin{aligned} & (\mathbf{W}_1^{(0)}, \mathbf{b}_1^{(0)}), \dots, (\mathbf{W}_1^{(L_1-1)}, \mathbf{b}_1^{(L_1-1)}), \left( \begin{pmatrix} \mathbf{W}_1^{(L_1)} \\ -\mathbf{W}_1^{(L_1)} \end{pmatrix}, \begin{pmatrix} \mathbf{b}_1^{(L_1)} \\ -\mathbf{b}_1^{(L_1)} \end{pmatrix} \right), \\ & ((\mathbf{W}_2^{(0)}, -\mathbf{W}_2^{(0)}), \mathbf{b}_2^{(0)}), (\mathbf{W}_2^{(1)}, \mathbf{b}_2^{(1)}), \dots, (\mathbf{W}_2^{(L_2)}, \mathbf{b}_2^{(L_2)}). \end{aligned}$$

下述引理汇总这些构造的性质.

**引理 5.2** (复合): 设  $\Phi_1, \Phi_2$  是架构分别为  $(\sigma_{\text{ReLU}}; d_0^1, \dots, d_{L_1+1}^1)$  和  $(\sigma_{\text{ReLU}}; d_0^2, \dots, d_{L_2+1}^2)$  的神经网络, 并假设  $d_{L_1+1}^1 = d_0^2$ . 则对所有  $\mathbf{x} \in \mathbb{R}^{d_0^1}$ ,

$$(\Phi_2 \circ \Phi_1)(\mathbf{x}) = (\Phi_2 \bullet \Phi_1)(\mathbf{x}) = \Phi_2(\Phi_1(\mathbf{x})).$$

此外,

$$\begin{aligned}\text{width}(\Phi_2 \circ \Phi_1) &\leq \max\{\text{width}(\Phi_1), \text{width}(\Phi_2)\}, \\ \text{depth}(\Phi_2 \circ \Phi_1) &= \text{depth}(\Phi_1) + \text{depth}(\Phi_2), \\ \text{size}(\Phi_2 \circ \Phi_1) &\leq \text{size}(\Phi_1) + \text{size}(\Phi_2) + (d_{L_1}^1 + 1)d_1^2,\end{aligned}$$

且

$$\begin{aligned}\text{width}(\Phi_2 \bullet \Phi_1) &\leq 2 \max\{\text{width}(\Phi_1), \text{width}(\Phi_2)\}, \\ \text{depth}(\Phi_2 \bullet \Phi_1) &= \text{depth}(\Phi_1) + \text{depth}(\Phi_2) + 1, \\ \text{size}(\Phi_2 \bullet \Phi_1) &\leq 2(\text{size}(\Phi_1) + \text{size}(\Phi_2)).\end{aligned}$$

**证明:** 等式  $(\Phi_2 \circ \Phi_1)(\mathbf{x}) = (\Phi_2 \bullet \Phi_1)(\mathbf{x}) = \Phi_2(\Phi_1(\mathbf{x}))$  由构造立即得到, 宽度与深度的界同样如此. 为验证规模界, 注意  $\mathbf{W}_2^{(0)}\mathbf{W}_1^{(L_1)} \in \mathbb{R}^{d_1^2 \times d_{L_1}^1}$ , 故至多有  $d_1^2 d_{L_1}^1$  个非零元素; 又有  $\mathbf{W}_2^{(0)}\mathbf{b}_1^{(L_1)} + \mathbf{b}_2^{(0)} \in \mathbb{R}^{d_1^2}$ . 因而,  $\Phi_2 \circ \Phi_1$  的第  $L_1$  层至多有  $d_1^2(1 + d_{L_1}^1)$  个非零元素, 其余结论由构造显然成立.  $\square$

若把线性变换视为深度为 0 的神经网络, 则当  $\Phi_1$  或  $\Phi_2$  为线性映射时, 上述引理仍然成立.

### 5.1.3 并行化

设  $(\Phi_i)_{i=1}^m$  是架构分别为  $(\sigma_{\text{ReLU}}; d_0^i, \dots, d_{L_i+1}^i)$  的神经网络. 现构造实现如下函数的神经网络  $(\Phi_1, \dots, \Phi_m)$ :

$$\begin{aligned}(\Phi_1, \dots, \Phi_m) : \mathbb{R}^{\sum_{j=1}^m d_0^j} &\rightarrow \mathbb{R}^{\sum_{j=1}^m d_{L_j+1}^j}, \\ (\mathbf{x}_1, \dots, \mathbf{x}_m) &\mapsto (\Phi_1(\mathbf{x}_1), \dots, \Phi_m(\mathbf{x}_m)).\end{aligned}\tag{5.1.1}$$

先假设  $L_1 = \dots = L_m = L$ , 并以如下权重-偏置序列定义  $(\Phi_1, \dots, \Phi_m)$ :

$$\left( \left( \begin{pmatrix} \mathbf{W}_1^{(0)} & & \\ & \ddots & \\ & & \mathbf{W}_m^{(0)} \end{pmatrix}, \begin{pmatrix} \mathbf{b}_1^{(0)} \\ \vdots \\ \mathbf{b}_m^{(0)} \end{pmatrix} \right), \dots, \left( \begin{pmatrix} \mathbf{W}_1^{(L)} & & \\ & \ddots & \\ & & \mathbf{W}_m^{(L)} \end{pmatrix}, \begin{pmatrix} \mathbf{b}_1^{(L)} \\ \vdots \\ \mathbf{b}_m^{(L)} \end{pmatrix} \right) \right), \tag{5.1.2}$$

其中矩阵应理解为以零填充的分块对角矩阵. 一般情形下, 各  $\Phi_j$  的深度可能不同. 令  $L_{\max} := \max_{1 \leq i \leq m} L_i$  及  $I := \{1 \leq i \leq m \mid L_i < L_{\max}\}$ . 对  $j \in I^c$  令  $\tilde{\Phi}_j := \Phi_j$ ; 对每个  $j \in I$  令

$$\tilde{\Phi}_j := \Phi_{L_{\max}-L_j}^{\text{id}} \circ \Phi_j. \tag{5.1.3}$$

最后定义

$$(\Phi_1, \dots, \Phi_m) := (\tilde{\Phi}_1, \dots, \tilde{\Phi}_m). \tag{5.1.4}$$

**引理 5.3** (并行化): 设  $m \in \mathbb{N}$ , 且  $(\Phi_i)_{i=1}^m$  是架构分别为  $(\sigma_{\text{ReLU}}; d_0^i, \dots, d_{L_i+1}^i)$  的神经网络. 则

$$(\Phi_1, \dots, \Phi_m)(\mathbf{x}) = (\Phi_1(\mathbf{x}_1), \dots, \Phi_m(\mathbf{x}_m))$$

对所有  $\mathbf{x} \in \mathbb{R}^{\sum_{j=1}^m d_0^j}$  成立. 此外, 令  $L_{\max} := \max_{j \leq m} L_j$ , 则

$$\text{width}((\Phi_1, \dots, \Phi_m)) \leq 2 \sum_{j=1}^m \text{width}(\Phi_j), \quad (5.1.5a)$$

$$\text{depth}((\Phi_1, \dots, \Phi_m)) = \max_{j \leq m} \text{depth}(\Phi_j), \quad (5.1.5b)$$

$$\text{size}((\Phi_1, \dots, \Phi_m)) \leq 2 \sum_{j=1}^m \text{size}(\Phi_j) + 2 \sum_{j=1}^m (L_{\max} - L_j) d_{L_j+1}^j. \quad (5.1.5c)$$

**证明:** 除规模界外, 其余断言均由构造立即得到. 对规模界, 按构造, 式 (5.1.3) 中各  $(\Phi_i)_{i=1}^m$  的规模直接相加, 而每个  $\Phi_i$  的规模可由引理 5.2 控制.  $\square$

若所有输入维数  $d_0^1 = \dots = d_0^m =: d_0$  均相同, 还会使用共享输入的并行化 (parallelization with shared inputs). 它实现从  $\mathbb{R}^{d_0}$  到  $\mathbb{R}^{d_{L_1+1}^1 + \dots + d_{L_m+1}^m}$  的函数

$$\mathbf{x} \mapsto (\Phi_1(\mathbf{x}), \dots, \Phi_m(\mathbf{x})).$$

对构造 (5.1.2) 而言, 唯一变化是把分块对角矩阵  $\text{diag}(\mathbf{W}_1^{(0)}, \dots, \mathbf{W}_m^{(0)})$  换成  $\mathbb{R}^{\sum_{j=1}^m d_1^j \times d_0^1}$  中把  $\mathbf{W}_1^{(0)}, \dots, \mathbf{W}_m^{(0)}$  逐个纵向叠放的矩阵. 类似地, 也允许  $\Phi_j$  只取  $\mathbf{x}$  的部分分量作为输入. 共享输入的并行化仍记为  $(\Phi_j)_{j=1}^m$ , 其确切含义总能由语境判断. 注意, 引理 5.3 在此情形下仍成立.

#### 5.1.4 线性组合

设  $m \in \mathbb{N}$ , 且  $(\Phi_i)_{i=1}^m$  是架构分别为  $(\sigma_{\text{ReLU}}; d_0^i, \dots, d_{L_i+1}^i)$  的 ReLU 神经网络. 假设  $d_{L_1+1}^1 = \dots = d_{L_m+1}^m$ , 即  $\Phi_1, \dots, \Phi_m$  具有相同输出维数. 对标量  $\alpha_j \in \mathbb{R}$ , 希望构造实现下述函数的 ReLU 神经网络  $\sum_{j=1}^m \alpha_j \Phi_j$ :

$$\begin{cases} \mathbb{R}^{\sum_{j=1}^m d_0^j} \rightarrow \mathbb{R}^{d_{L_1+1}^1}, \\ (\mathbf{x}_1, \dots, \mathbf{x}_m) \mapsto \sum_{j=1}^m \alpha_j \Phi_j(\mathbf{x}_j). \end{cases}$$

这相当于并行化  $(\Phi_1, \dots, \Phi_m)$  与线性变换  $(\mathbf{z}_1, \dots, \mathbf{z}_m) \mapsto \sum_{j=1}^m \alpha_j \mathbf{z}_j$  的复合.

**引理 5.4** (线性组合): 设  $m \in \mathbb{N}$ , 且  $(\Phi_i)_{i=1}^m$  是架构分别为  $(\sigma_{\text{ReLU}}; d_0^i, \dots, d_{L_i+1}^i)$  的神经网络. 假设  $d_{L_1+1}^1 = \dots = d_{L_m+1}^m$ , 令  $\alpha \in \mathbb{R}^m$  及  $L_{\max} := \max_{j \leq m} L_j$ . 则存在神经网络  $\sum_{j=1}^m \alpha_j \Phi_j$ , 使得对所有  $\mathbf{x} = (\mathbf{x}_j)_{j=1}^m \in \mathbb{R}^{\sum_{j=1}^m d_0^j}$ ,

$$\left( \sum_{j=1}^m \alpha_j \Phi_j \right) (\mathbf{x}) = \sum_{j=1}^m \alpha_j \Phi_j(\mathbf{x}_j).$$

此外,

$$\text{width}\left(\sum_{j=1}^m \alpha_j \Phi_j\right) \leq 2 \sum_{j=1}^m \text{width}(\Phi_j), \quad (5.1.6a)$$

$$\text{depth}\left(\sum_{j=1}^m \alpha_j \Phi_j\right) = \max_{j \leq m} \text{depth}(\Phi_j), \quad (5.1.6b)$$

$$\text{size}\left(\sum_{j=1}^m \alpha_j \Phi_j\right) \leq 2 \sum_{j=1}^m \text{size}(\Phi_j) + 2 \sum_{j=1}^m (L_{\max} - L_j) d_{L_j+1}^j. \quad (5.1.6c)$$

**证明:**  $\sum_{j=1}^m \alpha_j \Phi_j$  的构造与  $(\Phi_1, \dots, \Phi_m)$  类似: 先定义相同深度网络的线性组合. 权重按 (5.1.2) 选取, 但把最后一个线性变换替换为

$$\left( (\alpha_1 \mathbf{W}_1^{(L)} \dots \alpha_m \mathbf{W}_m^{(L)}), \sum_{j=1}^m \alpha_j \mathbf{b}_j^{(L)} \right).$$

对一般深度, 定义网络之和为 (5.1.3) 中延拓网络  $\tilde{\Phi}_i$  之和. 引理的全部断言均由此构造立即得到.  $\square$

当  $d_0^1 = \dots = d_0^m =: d_0$  (全部网络具有相同输入维数) 时, 也考虑共享输入的线性组合 (linear combinations with shared inputs), 即实现

$$\mathbf{x} \mapsto \sum_{j=1}^m \alpha_j \Phi_j(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^{d_0}$$

的神经网络. 这只需作与第 5.1.3 节末尾相同的微调. 引理 5.4 仍然成立; 记号上也不区分是否共享输入.

## 5.2 连续分段线性函数

本节把 ReLU 神经网络与一大类函数联系起来. 首先正式引入从集合  $\Omega \subseteq \mathbb{R}^d$  到  $\mathbb{R}$  的连续分段线性函数; 以下定义特别允许  $\Omega = \mathbb{R}^d$ .

**定义 5.5:** 设  $\Omega \subseteq \mathbb{R}^d$ ,  $d \in \mathbb{N}$ . 若  $f \in C^0(\Omega)$ , 且存在  $n \in \mathbb{N}$  个仿射函数  $g_j: \mathbb{R}^d \rightarrow \mathbb{R}$ ,  $g_j(\mathbf{x}) = \mathbf{w}_j^\top \mathbf{x} + b_j$ , 使得对每个  $\mathbf{x} \in \Omega$ , 至少有一个  $j \in \{1, \dots, n\}$  满足  $f(\mathbf{x}) = g_j(\mathbf{x})$ , 则称函数  $f: \Omega \rightarrow \mathbb{R}$  是连续分段线性的 (continuous, piecewise linear (cpwl)). 当  $m > 1$  时, 称  $f: \Omega \rightarrow \mathbb{R}^m$  是连续分段线性的, 当且仅当  $f$  的每个分量都是连续分段线性的.

**注 5.6:** 定义 5.5 中的“连续分段线性函数”实际上是分段仿射函数. 为与文献保持一致, 仍使用缩写 cpwl.  $\diamond$

下文也把  $f$  等于某个  $g_j$  的连通区域称为区域或片 (region or piece). 若 cpwl 函数  $f$  有  $q \in \mathbb{N}$  个区域, 而  $n \in \mathbb{N}$  表示仿射函数数量, 则  $n \leq q$ .

映射  $\mathbf{x} \mapsto \sigma_{\text{ReLU}}(\mathbf{w}^\top \mathbf{x} + b)$  是只有一个神经元的 ReLU 神经网络, 也是具有两个区域的 cpwl 函数. 因而, 每个 ReLU 神经网络都是 cpwl 函数的线性组合反复复合而

成. 不难看出,  $\text{cpwl}$  函数集合关于复合与线性组合封闭, 所以每个  $\text{ReLU}$  神经网络都是  $\text{cpwl}$  函数. 有趣的是, 反向命题也成立: 每个  $\text{cpwl}$  函数都能由  $\text{ReLU}$  神经网络表示. 因此, 任意  $\text{ReLU}$  神经网络实现的函数类可与  $\text{cpwl}$  函数类等同起来.

**定理 5.7:** 设  $d \in \mathbb{N}$ 、 $\Omega \subseteq \mathbb{R}^d$  为凸集, 并设  $f: \Omega \rightarrow \mathbb{R}$  是具有定义 5.5 中  $n \in \mathbb{N}$  个仿射函数的  $\text{cpwl}$  函数. 则存在  $\text{ReLU}$  神经网络  $\Phi^f$ , 使得对所有  $\mathbf{x} \in \Omega$  都有  $\Phi^f(\mathbf{x}) = f(\mathbf{x})$ , 且

$$\text{size}(\Phi^f) = O(dn2^n), \quad \text{width}(\Phi^f) = O(dn2^n), \quad \text{depth}(\Phi^f) = O(n).$$

与定理 5.7 类似的命题见文献 [9, 126]. 这些文献给出的构造, 其深度关于  $d$  为对数阶且与  $n$  无关, 但规模界显著更大. 下文将看到, 定理 5.7 可由文献 [303] 中的著名结果直接推出; 另见文献 [231], 更尖锐的界见文献 [320]. 该结果说明, 每个  $\text{cpwl}$  函数都能写成某些仿射函数的有限最小值的有限最大值.

**命题 5.8:** 设  $d \in \mathbb{N}$ 、 $\Omega \subseteq \mathbb{R}^d$  为凸集, 并设  $f: \Omega \rightarrow \mathbb{R}$  是具有定义 5.5 中  $n \in \mathbb{N}$  个仿射函数的  $\text{cpwl}$  函数. 则存在  $m \in \mathbb{N}$  以及集合  $s_j \subseteq \{1, \dots, n\}$  ( $j \in \{1, \dots, m\}$ ), 使得

$$f(\mathbf{x}) = \max_{1 \leq j \leq m} \min_{i \in s_j} g_i(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \Omega. \quad (5.2.1)$$

**证明:** 步骤 1. 先设  $d = 1$ , 即  $\Omega \subseteq \mathbb{R}$  是一个可能无界的区间, 且对每个  $x \in \Omega$ , 存在  $j \in \{1, \dots, n\}$ , 使得  $g_j(x) := w_j x + b_j$  满足  $f(x) = g_j(x)$ . 不失一般性, 可设所有  $i \neq j$  都有  $g_i \neq g_j$ . 因为  $g_j$  的图像是直线, 所以它们在  $\Omega$  中至多相交于有限多个点.

由  $f$  连续可知, 存在覆盖  $\Omega$  的有限多个区间, 使得  $f$  在每个区间上都等于某个  $g_j$ . 对每个  $x \in \Omega$ , 令

$$s_x := \{1 \leq j \leq n \mid g_j(x) \geq f(x)\}, \quad f_x(y) := \min_{j \in s_x} g_j(y) \quad \text{对所有 } y \in \Omega.$$

显然  $f_x(x) = f(x)$ . 进一步断言

$$f_x(y) \leq f(y) \quad \text{对所有 } y \in \Omega. \quad (5.2.2)$$

于是

$$f(y) = \max_{x \in \Omega} f_x(y) = \max_{x \in \Omega} \min_{j \in s_x} g_j(y) \quad \text{对所有 } y \in \mathbb{R}.$$

因为  $\{1, \dots, n\}$  的子集只有有限种选法, 所以 (5.2.1) 在  $d = 1$  时成立.

下面验证断言 (5.2.2). 固定  $y \neq x \in \Omega$ . 不失一般性, 设  $x < y$ , 并取  $x = x_0 < \dots < x_k = y$ , 使得对每个  $i \in \{1, \dots, k\}$ ,  $f|_{[x_{i-1}, x_i]}$  等于某个  $g_j$ . 要证明 (5.2.2), 只需证明至少存在一个  $j$ , 使得  $g_j(x_0) \geq f(x_0)$  且  $g_j(x_k) \leq f(x_k)$ . 当  $k = 1$  时显然成立, 以下作归纳. 假设  $k - 1$  时成立, 并考虑分割  $x_0 < \dots < x_k$ . 取  $r \in \{1, \dots, n\}$ , 使得  $f|_{[x_0, x_1]} = g_r|_{[x_0, x_1]}$ . 对区间  $[x_1, x_k]$  应用归纳假设, 可找到  $j \in \{1, \dots, n\}$ , 使得  $g_j(x_1) \geq f(x_1)$  且  $g_j(x_k) \leq f(x_k)$ . 若  $g_j(x_0) \geq f(x_0)$ , 则  $g_j$  即为所求. 否则  $g_j(x_0) < f(x_0)$ . 此时

$$g_r(x_0) = f(x_0) > g_j(x_0), \quad g_r(x_1) = f(x_1) \leq g_j(x_1).$$



因而对所有  $x \geq x_1$  都有  $g_r(x) \leq g_j(x)$ , 特别地  $g_r(x_k) \leq g_j(x_k)$ , 故  $g_r$  即为所求.

步骤 2. 对一般的  $d \in \mathbb{N}$ , 令  $g_j(\mathbf{x}) := \mathbf{w}_j^\top \mathbf{x} + b_j$  ( $j = 1, \dots, n$ ). 对每个  $\mathbf{x} \in \Omega$ , 令

$$s_{\mathbf{x}} := \{1 \leq j \leq n \mid g_j(\mathbf{x}) \geq f(\mathbf{x})\}, \quad f_{\mathbf{x}}(\mathbf{y}) := \min_{j \in s_{\mathbf{x}}} g_j(\mathbf{y}) \quad \text{对所有 } \mathbf{y} \in \Omega.$$

对任意穿过  $\mathbf{x}$  的一维仿射子空间  $S \subseteq \mathbb{R}^d$ , 考虑直线 (线段)  $I := S \cap \Omega$ . 因为  $\Omega$  为凸集, 所以  $I$  连通. 由步骤 1, 在整个  $I$  上有

$$f(\mathbf{y}) = \max_{\mathbf{x} \in \Omega} f_{\mathbf{x}}(\mathbf{y}) = \max_{\mathbf{x} \in \Omega} \min_{j \in s_{\mathbf{x}}} g_j(\mathbf{y}).$$

因  $I$  任意, 该公式对所有  $\mathbf{y} \in \Omega$  成立. 与步骤 1 相同, 这再次推出 (5.2.1).  $\square$

**注 5.9:** 对任意  $a_1, \dots, a_k \in \mathbb{R}$ , 有  $\min\{-a_1, \dots, -a_k\} = -\max\{a_1, \dots, a_k\}$ . 因而, 在命题 5.8 的设定下, 存在  $\tilde{m} \in \mathbb{N}$  和集合  $\tilde{s}_j \subseteq \{1, \dots, n\}$  ( $j = 1, \dots, \tilde{m}$ ), 使得对所有  $\mathbf{x} \in \Omega$ ,

$$\begin{aligned} f(\mathbf{x}) &= -(-f(\mathbf{x})) = -\max_{1 \leq j \leq \tilde{m}} \min_{i \in \tilde{s}_j} (-g_i(\mathbf{x})) \\ &= -\max_{1 \leq j \leq \tilde{m}} \left( -\max_{i \in \tilde{s}_j} g_i(\mathbf{x}) \right) \\ &= \min_{1 \leq j \leq \tilde{m}} \left( \max_{i \in \tilde{s}_j} g_i(\mathbf{x}) \right). \end{aligned}$$

$\diamond$

因此, 要证明定理 5.7, 只需说明最小值与最大值可由 ReLU 神经网络表示.

**引理 5.10:** 对每个  $x, y \in \mathbb{R}$ , 都有

$$\begin{aligned} \min\{x, y\} &= \sigma_{\text{ReLU}}(y) - \sigma_{\text{ReLU}}(-y) - \sigma_{\text{ReLU}}(y - x) \in \mathcal{N}_2^1(\sigma_{\text{ReLU}}; 1, 3), \\ \max\{x, y\} &= \sigma_{\text{ReLU}}(y) - \sigma_{\text{ReLU}}(-y) + \sigma_{\text{ReLU}}(x - y) \in \mathcal{N}_2^1(\sigma_{\text{ReLU}}; 1, 3). \end{aligned}$$

**证明:** 有

$$\begin{aligned} \max\{x, y\} &= y + \begin{cases} 0 & \text{若 } y > x, \\ x - y & \text{若 } x \geq y, \end{cases} \\ &= y + \sigma_{\text{ReLU}}(x - y). \end{aligned}$$

利用  $y = \sigma_{\text{ReLU}}(y) - \sigma_{\text{ReLU}}(-y)$  即得最大值的断言. 对最小值, 只需注意  $\min\{x, y\} = -\max\{-x, -y\}$ .  $\square$

对  $n \geq 2$  个输入的最小值, 可反复应用引理 5.10 的构造计算. 下述引理描述所得神经网络.

**引理 5.11:** 对每个  $n \geq 2$ , 存在神经网络  $\Phi_n^{\min} : \mathbb{R}^n \rightarrow \mathbb{R}$ , 满足

$$\text{size}(\Phi_n^{\min}) \leq 16n, \quad \text{width}(\Phi_n^{\min}) \leq 3n, \quad \text{depth}(\Phi_n^{\min}) \leq \lceil \log_2(n) \rceil,$$

且  $\Phi_n^{\min}(x_1, \dots, x_n) = \min_{1 \leq j \leq n} x_j$ . 类似地, 存在实现最大值并满足相同复杂度界的神经网络  $\Phi_n^{\max} : \mathbb{R}^n \rightarrow \mathbb{R}$ .




图 5.1: 引理 5.10 中神经网络的示意图；仅绘出权重非零的边。

**证明：** 下文始终以  $\Phi_2^{\min} : \mathbb{R}^2 \rightarrow \mathbb{R}$  表示引理 5.10 中的神经网络。它的深度为 1、规模为 7；由于全部偏置均为零，只需数图 5.1 中的连边数量。

步骤 1. 先考虑  $n = 2^k$  (某个  $k \in \mathbb{N}$ ) 的情形，对  $k$  归纳。当  $k = 1$  时断言已经证明。当  $k \geq 2$  时，令

$$\Phi_{2^k}^{\min} := \Phi_2^{\min} \circ (\Phi_{2^{k-1}}^{\min}, \Phi_{2^{k-1}}^{\min}). \quad (5.2.3)$$

由引理 5.2 与引理 5.3,

$$\text{depth}(\Phi_{2^k}^{\min}) \leq \text{depth}(\Phi_2^{\min}) + \text{depth}(\Phi_{2^{k-1}}^{\min}) \leq \cdots \leq k.$$

接着控制网络规模。因引理 5.10 中的  $\Phi_2^{\min}$  没有偏置，该网络全部偏置均为 0，所以  $\Phi_{2^k}^{\min}$  的规模就是图中的连边数。仔细考察网络架构（见图 5.2）可得

$$\begin{aligned} \text{size}(\Phi_{2^k}^{\min}) &= 4 \cdot 2^{k-1} + \sum_{j=0}^{k-2} 12 \cdot 2^j + 3 \\ &= 2n + 12(2^{k-1} - 1) + 3 = 2n + 6n - 9 \leq 8n, \end{aligned}$$

且  $\text{width}(\Phi_{2^k}^{\min}) \leq (3/2)2^k$ . 这便完成  $n = 2^k$  情形的证明。

步骤 2. 对一般情形，先令

$$\Phi_1^{\min}(x) := x \quad \text{对所有 } x \in \mathbb{R},$$

即取  $\mathbb{R}$  上的恒等映射；它是线性变换，形式上是深度为 0 的神经网络。对所有  $n \geq 2$ ，令

$$\Phi_n^{\min} := \Phi_2^{\min} \circ \begin{cases} (\Phi_1^{\text{id}} \circ \Phi_{\lfloor n/2 \rfloor}^{\min}, \Phi_{\lfloor n/2 \rfloor}^{\min}) & \text{若 } n \in \{2^k + 1 \mid k \in \mathbb{N}\}, \\ (\Phi_{\lfloor n/2 \rfloor}^{\min}, \Phi_{\lfloor n/2 \rfloor}^{\min}) & \text{否则.} \end{cases} \quad (5.2.4)$$

当  $n \geq 2$  是 2 的幂时，(5.2.4) 中的第一种情形绝不会发生，故该定义把 (5.2.3) 推广到任意  $n \geq 2$ 。

为分析 (5.2.4)，先考察深度，并断言对所有  $k \in \mathbb{N}$ ，

$$\text{depth}(\Phi_n^{\min}) = k \quad \text{对所有 } 2^{k-1} < n \leq 2^k.$$

对  $k$  归纳。  $k = 1$  时显然。对归纳步骤，假设命题对某个固定  $k \in \mathbb{N}$  成立，并固定满足  $2^k < n \leq 2^{k+1}$  的整数  $n$ 。则

$$\begin{aligned} \left\lceil \frac{n}{2} \right\rceil &\in (2^{k-1}, 2^k] \cap \mathbb{N}, \\ \left\lfloor \frac{n}{2} \right\rfloor &\in \begin{cases} \{2^{k-1}\} & \text{若 } n = 2^k + 1, \\ (2^{k-1}, 2^k] \cap \mathbb{N} & \text{否则.} \end{cases} \end{aligned}$$

利用归纳假设、式 (5.2.4) 以及引理 5.1 和引理 5.2, 得到

$$\text{depth}(\Phi_n^{\min}) = \text{depth}(\Phi_2^{\min}) + k = 1 + k,$$

从而证明断言.

对规模与宽度界只概述论证. 固定满足  $2^{k-1} < n \leq 2^k$  的  $n \in \mathbb{N}$ . 构造  $\Phi_n^{\min}$  所用子网络不多于  $\Phi_{2^k}^{\min}$ , 只是把若干  $\Phi_2^{\min} : \mathbb{R}^2 \rightarrow \mathbb{R}$  模块替换为  $\Phi_1^{\text{id}} : \mathbb{R} \rightarrow \mathbb{R}$ ; 见图 5.3.  $\Phi_1^{\text{id}}$  与  $\Phi_2^{\min}$  深度相同, 但宽度和连边数更小, 故  $\Phi_n^{\min}$  的宽度与规模均由  $\Phi_{2^k}^{\min}$  的相应量控制. 因为  $2^k \leq 2n$ , 步骤 1 的界即给出引理所述各界.

步骤 3. 对最大值, 定义

$$\Phi_n^{\max}(x_1, \dots, x_n) := -\Phi_n^{\min}(-x_1, \dots, -x_n).$$

□




图 5.2: 引理 5.11 证明步骤 1 中  $\Phi_{2^k}^{\min}$  神经网络的架构, 以及  $k = 3$  时每层之间的连边数量; 每个灰框对应图中的 12 条连边.

**定理 5.7 的证明:** 由命题 5.8, 神经网络

$$\Phi := \Phi_m^{\max} \bullet (\Phi_{|s_j|}^{\min})_{j=1}^m \bullet ((\mathbf{w}_i^\top \mathbf{x} + b_i)_{i \in s_j})_{j=1}^m$$

实现函数  $f$ .

因为  $\{1, \dots, n\}$  的子集共有  $2^n$  种选法, 所以  $m \leq 2^n$ . 又因每个  $s_j$  都是  $\{1, \dots, n\}$  的子集, 故  $|s_j| \leq n$ . 由引理 5.2、引理 5.3 和引理 5.11,

$$\begin{aligned} \text{depth}(\Phi) &\leq 2 + \text{depth}(\Phi_m^{\max}) + \max_{1 \leq j \leq m} \text{depth}(\Phi_{|s_j|}^{\min}) \\ &\leq 1 + \lceil \log_2(2^n) \rceil + \lceil \log_2(n) \rceil = O(n), \end{aligned}$$




图 5.3: 引理 5.11 证明步骤 2 中一般  $n$  的  $\Phi_n^{\min}$  构造.

并且

$$\begin{aligned} \text{width}(\Phi) &\leq 2 \max \left\{ \text{width}(\Phi_m^{\max}), \sum_{j=1}^m \text{width}(\Phi_{|s_j|}^{\min}), \sum_{j=1}^m \text{width}((\mathbf{w}_i^\top \mathbf{x} + b_i)_{i \in s_j}) \right\} \\ &\leq 2 \max \{ 3m, 3mn, mdn \} = O(dn2^n), \end{aligned}$$

以及

$$\begin{aligned} \text{size}(\Phi) &\leq 4 \left( \text{size}(\Phi_m^{\max}) + \text{size}((\Phi_{|s_j|}^{\min})_{j=1}^m) + \text{size}((\mathbf{w}_i^\top \mathbf{x} + b_i)_{i \in s_j})_{j=1}^m \right) \\ &\leq 4 \left( 16m + 2 \sum_{j=1}^m (16|s_j| + 2\lceil \log_2(n) \rceil) + nm(d+1) \right) \\ &= O(dn2^n). \end{aligned}$$

证明完毕. □

## 5.3 单纯形片

### 5.3.1 $\Omega$ 的三角剖分

在下文讨论中, 将把  $\Omega \subseteq \mathbb{R}^d$  划分为若干单纯形. 这种划分称为  $\Omega$  的三角剖分 (triangulation). 文献中常见的其他说法还有  $\Omega$  的镶嵌 (tessellation) 以及  $\Omega$  上的单纯形网格 (simplicial mesh). 为给出严格定义, 先回顾一些术语. 对集合  $S \subseteq \mathbb{R}^d$ , 记  $S$  的凸包为

$$\text{co}(S) := \left\{ \sum_{j=1}^n \alpha_j \mathbf{x}_j \mid n \in \mathbb{N}, \mathbf{x}_j \in S, \alpha_j \geq 0, \sum_{j=1}^n \alpha_j = 1 \right\}. \quad (5.3.1)$$

$n$ -单纯形是以一种特定意义相互独立的  $n \in \mathbb{N}$  个点的凸包. 下述定义对此作出严格说明.

**定义 5.12:** 设  $n \in \mathbb{N}_0$ 、 $d \in \mathbb{N}$  且  $n \leq d$ . 称  $\mathbf{x}_0, \dots, \mathbf{x}_n \in \mathbb{R}^d$  仿射无关 (affinely independent), 当且仅当  $n = 0$ , 或者  $n \geq 1$  且向量  $\mathbf{x}_1 - \mathbf{x}_0, \dots, \mathbf{x}_n - \mathbf{x}_0$  线性无关. 在这种情形下, 称  $\text{co}(\mathbf{x}_0, \dots, \mathbf{x}_n) := \text{co}(\{\mathbf{x}_0, \dots, \mathbf{x}_n\})$  为一个  $n$ -单纯形 ( $n$ -simplex).

如前所述, 三角剖分是指把一个空间划分为若干单纯形. 下面给出正式定义.

**定义 5.13:** 设  $d \in \mathbb{N}$ ,  $\Omega \subseteq \mathbb{R}^d$  为紧集. 设  $\mathcal{T}$  是由  $d$ -单纯形组成的有限集合, 并且对每个  $\tau \in \mathcal{T}$ , 集合  $V(\tau) \subseteq \Omega$  的基数为  $d+1$ , 且  $\tau = \text{co}(V(\tau))$ . 称  $\mathcal{T}$  为  $\Omega$  的正则三角剖分 (regular triangulation), 当且仅当

1.  $\bigcup_{\tau \in \mathcal{T}} \tau = \Omega$ ;
2. 对所有  $\tau, \tau' \in \mathcal{T}$ , 有  $\tau \cap \tau' = \text{co}(V(\tau) \cap V(\tau'))$ .

称  $\eta \in \mathcal{V} := \bigcup_{\tau \in \mathcal{T}} V(\tau)$  为该三角剖分的节点 (node) (或顶点), 称  $\tau \in \mathcal{T}$  为其单元 (element).




图 5.4: 第一个是正则三角剖分, 而第二个和第三个不是.

对节点集合为  $\mathcal{V}$  的正则三角剖分  $\mathcal{T}$ , 还引入常数

$$k_{\mathcal{T}} := \max_{\eta \in \mathcal{V}} |\{\tau \in \mathcal{T} \mid \eta \in \tau\}|, \quad (5.3.2)$$

它对应于共享同一节点的单元最大数目.

### 5.3.2 正则三角剖分的规模界

在本小节中, 始终设  $\mathcal{T}$  是  $\Omega$  的正则三角剖分, 并沿用定义 5.13 的记号. 若  $f$  是 cpwl 函数, 且对每个  $\tau \in \mathcal{T}$ ,  $f|_{\tau}$  都是仿射的, 则称  $f: \Omega \rightarrow \mathbb{R}$  关于  $\mathcal{T}$  是 cpwl 的. 本小节余下部分用于证明下述结果. 该结果最初由文献 [189] 以更具技术性的论证证明, 并把文献 [126] 中的早期结论推广到了任意三角剖分 (另见 subsection 5.3.3).

**定理 5.14:** 设  $d \in \mathbb{N}$ ,  $\Omega \subseteq \mathbb{R}^d$  为有界区域,  $\mathcal{T}$  是  $\Omega$  的正则三角剖分. 设  $f: \Omega \rightarrow \mathbb{R}$  关于  $\mathcal{T}$  是 cpwl 的, 且  $f|_{\partial\Omega} = 0$ . 则存在实现  $f$  的 ReLU 神经网络  $\Phi: \Omega \rightarrow \mathbb{R}$ , 并且

$$\text{size}(\Phi) = O(|\mathcal{T}|), \quad \text{width}(\Phi) = O(|\mathcal{T}|), \quad \text{depth}(\Phi) = O(1), \quad (5.3.3)$$

其中 Landau 记号中的常数依赖于  $d$  和式 (5.3.2) 中的  $k_{\mathcal{T}}$ .

我们把证明分解为若干引理. 证明策略是为  $\mathcal{T}$  上且在  $\Omega$  边界处为零的 cpwl 函数空间引入一组基. 随后将证明, 这组基由  $O(|\mathcal{T}|)$  个基函数组成, 并且每个基函数都可由规模仅依赖于  $k_{\mathcal{T}}$  和  $d$  的神经网络表示. 为构造这组基, 先指出单纯形上的仿射函数由其在节点处的取值唯一确定.

**引理 5.15:** 设  $d \in \mathbb{N}$ . 设  $\tau := \text{co}(\boldsymbol{\eta}_0, \dots, \boldsymbol{\eta}_d)$  是一个  $d$ -单纯形. 对任意  $y_0, \dots, y_d \in \mathbb{R}$ , 存在唯一的  $g \in \mathbb{P}_1(\mathbb{R}^d)$ , 使得  $g(\boldsymbol{\eta}_i) = y_i$ ,  $i = 0, \dots, d$ .

**证明:** 因为  $\boldsymbol{\eta}_1 - \boldsymbol{\eta}_0, \dots, \boldsymbol{\eta}_d - \boldsymbol{\eta}_0$  是  $\mathbb{R}^d$  的一组基, 所以存在唯一的  $\mathbf{w} \in \mathbb{R}^d$ , 使得对  $i = 1, \dots, d$  有  $\mathbf{w}^\top(\boldsymbol{\eta}_i - \boldsymbol{\eta}_0) = y_i - y_0$ . 此时  $g(\mathbf{x}) := \mathbf{w}^\top \mathbf{x} + (y_0 - \mathbf{w}^\top \boldsymbol{\eta}_0)$  即为所求. 此外, 对每个  $g \in \mathbb{P}_1$ , 只要  $\sum_{i=0}^d \alpha_i = 1$ , 就有  $g(\sum_{i=0}^d \alpha_i \boldsymbol{\eta}_i) = \sum_{i=0}^d \alpha_i g(\boldsymbol{\eta}_i)$  (一般而言, 若系数之和不为 1, 该等式并不成立). 因而,  $g$  由其在节点处的取值唯一确定.  $\square$

由于  $\Omega$  是所有  $\tau \in \mathcal{T}$  的并集, 关于  $\mathcal{T}$  的每个 cpwl 函数也就由其在节点处的取值唯一确定. 因此, 所需的基由关于  $\mathcal{T}$  的 cpwl 函数  $\varphi_{\boldsymbol{\eta}}: \Omega \rightarrow \mathbb{R}$  组成, 并满足

$$\varphi_{\boldsymbol{\eta}}(\boldsymbol{\mu}) = \delta_{\boldsymbol{\eta}\boldsymbol{\mu}} \quad \text{对所有 } \boldsymbol{\mu} \in \mathcal{V}, \quad (5.3.4)$$

其中  $\delta_{\boldsymbol{\eta}\boldsymbol{\mu}}$  表示 Kronecker delta. 暂且假设  $\varphi_{\boldsymbol{\eta}}$  定义良好, 则每个在边界  $\partial\Omega$  上为零的 cpwl 函数  $f: \Omega \rightarrow \mathbb{R}$  都可表示为

$$f(\mathbf{x}) = \sum_{\boldsymbol{\eta} \in \mathcal{V} \cap \overset{\circ}{\Omega}} f(\boldsymbol{\eta}) \varphi_{\boldsymbol{\eta}}(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \Omega.$$

注意, 只需对内部节点 (interior node) 集合  $\mathcal{V} \cap \overset{\circ}{\Omega}$  求和, 因为当  $\boldsymbol{\eta} \in \partial\Omega$  时  $f(\boldsymbol{\eta}) = 0$ . 为严格验证  $\varphi_{\boldsymbol{\eta}}$  的存在性与定义良好性, 先要用一个引理刻画三角剖分所谓“节点片”的边界: 对每个  $\boldsymbol{\eta} \in \mathcal{V}$ , 把节点  $\boldsymbol{\eta}$  的节点片 (patch)  $\omega(\boldsymbol{\eta})$  定义为所有包含  $\boldsymbol{\eta}$  的单元之并, 即

$$\omega(\boldsymbol{\eta}) := \bigcup_{\{\tau \in \mathcal{T} \mid \boldsymbol{\eta} \in \tau\}} \tau. \quad (5.3.5)$$

**引理 5.16:** 设  $\boldsymbol{\eta} \in \mathcal{V} \cap \overset{\circ}{\Omega}$  是内部节点. 则

$$\partial\omega(\boldsymbol{\eta}) = \bigcup_{\{\tau \in \mathcal{T} \mid \boldsymbol{\eta} \in \tau\}} \text{co}(V(\tau) \setminus \{\boldsymbol{\eta}\}).$$

图 5.5 给出了引理 5.16 的示意图. 引理 5.16 的证明技术性较强, 但仍是初等的. 因此这里只概述一般论证, 把细节留给读者在习题 5.28 中完成:  $\omega(\boldsymbol{\eta})$  的边界必包含于该节点片中所有  $\tau$  的边界之并. 因为  $\boldsymbol{\eta}$  是  $\Omega$  的内点, 所以它也必为  $\omega(\boldsymbol{\eta})$  的内点. 由此可




图 5.5: 二维情形下引理 5.16 的示意图. 节点片  $\omega(\eta)$  是所有包含  $\eta$  的 2-单纯形  $\tau_i$  的并. 它的边界由从每个  $\tau_i$  的节点中去掉中心节点后得到的所有 1-单纯形之并组成, 即各个  $V(\tau_i) \setminus \{\eta\}$  的凸包之并.

以证明: 对每个基数为  $k+1 \leq d$  的  $S := \{\eta_{i_0}, \dots, \eta_{i_k}\} \subseteq V(\tau)$ , 只要  $\eta \in S$ ,  $\text{co}(S)$  (这一  $k$  维流形) 的内部就属于  $\omega(\eta)$  的内部. 利用习题 5.28 后, 只需再验证当  $\eta \notin S$  时  $\text{co}(S) \subseteq \partial\omega(\eta)$ , 即可得到所声称的公式. 现在可以证明式 (5.3.4) 中基函数的定义良好性.

**引理 5.17:** 对每个内部节点  $\eta \in \mathcal{V} \cap \mathring{\Omega}$ , 存在唯一的 cpwl 函数  $\varphi_\eta : \Omega \rightarrow \mathbb{R}$  满足式 (5.3.4). 此外,  $\varphi_\eta$  可以表示为 ReLU 神经网络, 其规模、宽度和深度界仅依赖于  $d$  和  $k_{\mathcal{T}}$ .

**证明:** 由引理 5.15, 在每个  $\tau \in \mathcal{T}$  上, 仿射函数  $\varphi_\eta|_\tau$  都由其在  $\tau$  的节点处的取值唯一确定. 这定义了连续函数  $\varphi_\eta : \Omega \rightarrow \mathbb{R}$ . 事实上, 只要  $\tau \cap \tau' \neq \emptyset$ , 按照定义 5.13 的条件 2,  $\tau \cap \tau'$  就同时是  $\tau$  与  $\tau'$  的子单纯形. 因而再次应用引理 5.15 可知,  $\tau$  与  $\tau'$  上的仿射函数在  $\tau \cap \tau'$  上重合.

利用引理 5.15、引理 5.16 以及当  $\mu \neq \eta$  时  $\varphi_\eta(\mu) = 0$  这一事实, 可知  $\varphi_\eta$  在节点片  $\omega(\eta) \subseteq \Omega$  的边界上为零. 因此,  $\varphi_\eta$  在  $\Omega$  的边界上为零. 将其零延拓后, 得到 cpwl 函数  $\varphi_\eta : \mathbb{R}^d \rightarrow \mathbb{R}$ . 该函数只在满足  $\eta \in \tau$  的单元  $\tau$  上非零. 因而, 它是至多含  $n := k_{\mathcal{T}} + 1$  个仿射函数的 cpwl 函数. 由定理 5.7,  $\varphi_\eta$  可以表示为具有所述规模、宽度和深度界的 ReLU 神经网络; 应用定理 5.7 时使用了如下事实:  $\varphi_\eta$  (的延拓) 定义在凸区域  $\mathbb{R}^d$  上.  $\square$

最后, 定理 5.14 很容易由上述引理推出.

**定理 5.14 的证明:** 令

$$\Phi(x) := \sum_{\eta \in \mathcal{V} \cap \mathring{\Omega}} f(\eta) \varphi_\eta(x) \quad \text{对 } x \in \Omega. \quad (5.3.6)$$

则  $\Phi : \Omega \rightarrow \mathbb{R}$  对所有  $\eta \in \mathcal{V}$  都满足  $\Phi(\eta) = f(\eta)$ . 由引理 5.15, 这意味着  $f$  与  $\Phi$  在每个  $\tau$  上相等, 因而在整个  $\Omega$  上相等. 每个单元  $\tau$  都是  $d+1$  个节点  $\eta \in \mathcal{V}$  的凸包, 所以  $\mathcal{V}$  的基数不超过  $\mathcal{T}$  的基数乘以  $d+1$ . 因此, 式 (5.3.6) 中的求和含  $O(|\mathcal{T}|)$  项. 利用引理 5.4 和引理 5.17, 即得神经网络规模、宽度和深度的所述界.  $\square$



### 5.3.3 局部凸三角剖分的规模界

本小节假设三角剖分局部凸，并把定理 5.14 中常数对维数  $d$  以及与某个节点相接的单纯形最大数目  $k_{\mathcal{T}}$  的依赖关系明确写出；见式 (5.3.2). 因而，相比定理 5.14，这里的改进并不显著，读者初次阅读时可以跳过本小节. 尽管如此，这一最初出自文献 [126] 的证明完全是构造性的，并进一步揭示了 ReLU 网络如何表示函数. 先陈述所需的凸性约束.

**定义 5.18:** 称正则三角剖分  $\mathcal{T}$  局部凸 (locally convex)，当且仅当对所有内部节点  $\eta \in \mathcal{V} \cap \overset{\circ}{\Omega}$ ， $\omega(\eta)$  都是凸集.

下述定理是文献 [126, Theorem 3.1] 的一个变体.

**定理 5.19:** 设  $d \in \mathbb{N}$ ， $\Omega \subseteq \mathbb{R}^d$  为有界区域. 设  $\mathcal{T}$  是  $\Omega$  的局部凸正则三角剖分. 设  $f: \Omega \rightarrow \mathbb{R}$  关于  $\mathcal{T}$  是 cpwl 的，且  $f|_{\partial\Omega} = 0$ . 则存在与  $d$ 、 $f$  和  $\mathcal{T}$  均无关的常数  $C > 0$ ，并且存在神经网络  $\Phi^f: \Omega \rightarrow \mathbb{R}$  使得  $\Phi^f = f$ ，且

$$\begin{aligned} \text{size}(\Phi^f) &\leq C \cdot (1 + d^2 k_{\mathcal{T}} |\mathcal{T}|), \\ \text{width}(\Phi^f) &\leq C \cdot (1 + d \log(k_{\mathcal{T}}) |\mathcal{T}|), \\ \text{depth}(\Phi^f) &\leq C \cdot (1 + \log_2(k_{\mathcal{T}})). \end{aligned}$$

下文假设  $\mathcal{T}$  是局部凸三角剖分. 我们再次把定理的证明分解为若干引理. 首先证明凸节点片可写成有限多个半空间之交. 具体而言，把集合  $S$  的仿射包 (affine hull) 定义为

$$\text{aff}(S) := \left\{ \sum_{j=1}^n \alpha_j \mathbf{x}_j \mid n \in \mathbb{N}, \mathbf{x}_j \in S, \alpha_j \in \mathbb{R}, \sum_{j=1}^n \alpha_j = 1 \right\}. \quad (5.3.7)$$

下文对  $\tau \in \mathcal{T}$  和  $\eta \in V(\tau)$ ，令

$$H_0(\tau, \eta) := \text{aff}(V(\tau) \setminus \{\eta\})$$

为经过  $V(\tau) \setminus \{\eta\}$  中所有节点的仿射超平面，并进一步令

$$H_+(\tau, \eta) := \{\mathbf{x} \in \mathbb{R}^d \mid \mathbf{x} \text{ 与 } \eta \text{ 位于 } H_0(\tau, \eta) \text{ 的同一侧}\} \cup H_0(\tau, \eta).$$

**引理 5.20:** 设  $\eta$  是内部节点. 则节点片  $\omega(\eta)$  为凸集，当且仅当

$$\omega(\eta) = \bigcap_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}} H_+(\tau, \eta). \quad (5.3.8)$$

**证明:** 右端是有限多个 (凸) 半空间之交，因而本身为凸集. 还需证明，若  $\omega(\eta)$  为凸集，则式 (5.3.8) 成立. 先证 “ $\supseteq$ ”. 假设  $\mathbf{x} \notin \omega(\eta)$ . 则线段  $\text{co}(\{\mathbf{x}, \eta\})$  必穿过  $\partial\omega(\eta)$ ；由引理 5.16，这意味着存在满足  $\eta \in \tau$  的  $\tau \in \mathcal{T}$ ，使得  $\text{co}(\{\mathbf{x}, \eta\})$  穿过  $\text{aff}(V(\tau) \setminus \{\eta\}) = H_0(\tau, \eta)$ . 因此， $\eta$  与  $\mathbf{x}$  位于该仿射超平面的不同侧，这就证明了 “ $\supseteq$ ”. 再证 “ $\subseteq$ ”. 取满足  $\eta \in \tau$  的  $\tau \in \mathcal{T}$ ，并固定  $H_+(\tau, \eta)$  补集中的  $\mathbf{x}$ . 假设  $\mathbf{x} \in \omega(\eta)$ . 由凸性，便有  $\text{co}(\{\mathbf{x}\} \cup \tau) \subseteq \omega(\eta)$ . 这意味着  $\text{co}(V(\tau) \setminus \{\eta\})$  中存在一点属于  $\omega(\eta)$  的内部，与引理 5.16 矛盾. 因而  $\mathbf{x} \notin \omega(\eta)$ .  $\square$

上述引理使我们能够显式构造式 (5.3.4) 中的基函数  $\varphi_\eta$ . 为此, 下文对  $\tau \in \mathcal{T}$  和  $\eta \in V(\tau)$ , 以  $g_{\tau,\eta} \in \mathbb{P}_1(\mathbb{R}^d)$  表示满足

$$g_{\tau,\eta}(\mu) = \begin{cases} 1 & \text{若 } \eta = \mu, \\ 0 & \text{若 } \eta \neq \mu \end{cases} \quad \text{对所有 } \mu \in V(\tau)$$

的仿射函数. 由引理 5.15, 该函数存在且唯一. 注意, 对所有  $\mathbf{x} \in \tau$ , 都有  $\varphi_\eta(\mathbf{x}) = g_{\tau,\eta}(\mathbf{x})$ .

**引理 5.21:** 设  $\eta \in \mathcal{V} \cap \mathring{\Omega}$  是内部节点, 且  $\omega(\eta)$  是凸节点片. 则

$$\varphi_\eta(\mathbf{x}) = \max \left\{ 0, \min_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}} g_{\tau,\eta}(\mathbf{x}) \right\} \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^d. \quad (5.3.9)$$

**证明:** 先设  $\mathbf{x} \notin \omega(\eta)$ . 由引理 5.20, 存在满足  $\eta \in \tau$  的  $\tau \in \mathcal{T}$ , 使得  $\mathbf{x}$  位于  $H_+(\tau, \eta)$  的补集中. 注意

$$g_{\tau,\eta}|_{H_+(\tau,\eta)} \geq 0 \quad \text{且} \quad g_{\tau,\eta}|_{H_+(\tau,\eta)^c} < 0. \quad (5.3.10)$$

因此

$$\min_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}} g_{\tau,\eta}(\mathbf{x}) < 0 \quad \text{对所有 } \mathbf{x} \in \omega(\eta)^c,$$

即式 (5.3.9) 对所有  $\mathbf{x} \in \mathbb{R}^d \setminus \omega(\eta)$  成立. 接着, 设  $\tau, \tau' \in \mathcal{T}$ , 且  $\eta \in \tau, \eta \in \tau'$ . 我们希望证明, 对所有  $\mathbf{x} \in \tau$ , 都有  $g_{\tau,\eta}(\mathbf{x}) \leq g_{\tau',\eta}(\mathbf{x})$ . 因为对所有  $\mathbf{x} \in \tau$  都有  $g_{\tau,\eta}(\mathbf{x}) = \varphi_\eta(\mathbf{x})$ , 这将完成式 (5.3.9) 的证明. 由引理 5.20,

$$\mu \in H_+(\tau', \eta) \quad \text{对所有 } \mu \in V(\tau).$$

因而由式 (5.3.10),

$$g_{\tau',\eta}(\mu) \geq 0 = g_{\tau,\eta}(\mu) \quad \text{对所有 } \mu \in V(\tau) \setminus \{\eta\}.$$

此外,  $g_{\tau,\eta}(\eta) = g_{\tau',\eta}(\eta) = 1$ . 因此, 对所有  $\mu \in V(\tau')$ , 有  $g_{\tau,\eta}(\mu) \geq g_{\tau',\eta}(\mu)$ , 从而

$$g_{\tau',\eta}(\mathbf{x}) \geq g_{\tau,\eta}(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \text{co}(V(\tau')) = \tau'.$$

□

**定理 5.19 的证明:** 对每个内部节点  $\eta \in \mathcal{V} \cap \mathring{\Omega}$ , 式 (5.3.4) 中的 cpwl 基函数  $\varphi_\eta$  都可以写成式 (5.3.9) 的形式, 即

$$\varphi_\eta(\mathbf{x}) = \sigma \bullet \Phi_{|\{\tau \in \mathcal{T} \mid \eta \in \tau\}|}^{\min} \bullet (g_{\tau,\eta}(\mathbf{x}))_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}},$$

其中  $(g_{\tau,\eta}(\mathbf{x}))_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}}$  表示对所有满足  $\eta \in \tau$  的  $\tau \in \mathcal{T}$ , 将函数  $g_{\tau,\eta}(\mathbf{x})$  以共享输入方式并行化.

对该神经网络, 利用  $|\{\tau \in \mathcal{T} \mid \eta \in \tau\}| \leq k_{\mathcal{T}}$  以及引理 5.2, 有

$$\begin{aligned} \text{size}(\varphi_\eta) &\leq 4(\text{size}(\sigma) + \text{size}(\Phi_{|\{\tau \in \mathcal{T} \mid \eta \in \tau\}|}^{\min})) + \text{size}((g_{\tau,\eta})_{\{\tau \in \mathcal{T} \mid \eta \in \tau\}})) \\ &\leq 4(2 + 16k_{\mathcal{T}} + k_{\mathcal{T}}d) \end{aligned} \quad (5.3.11)$$

并且类似地,

$$\text{depth}(\varphi_\eta) \leq 4 + \lceil \log_2(k_\mathcal{T}) \rceil, \quad \text{width}(\varphi_\eta) \leq \max\{1, 3k_\mathcal{T}, d\}. \quad (5.3.12)$$

对每个内部节点, 与该节点相接的单纯形数目必大于或等于  $d$ , 故下文可以假设  $\max\{k_\mathcal{T}, d\} = k_\mathcal{T}$  (否则不存在内部节点, 而函数  $f$  恒为 0). 与定理 5.14 的证明相同, 神经网络

$$\Phi(\mathbf{x}) := \sum_{\eta \in \mathcal{V} \cap \bar{\Omega}} f(\eta) \varphi_\eta(\mathbf{x})$$

在整个  $\Omega$  上实现函数  $f$ . 由于节点数  $|\mathcal{V}|$  不超过  $(d+1)|\mathcal{T}|$ , 应用引理 5.4 即得所需各界.  $\square$

## 5.4 Hölder 连续函数的收敛率

定理 5.14 立即给出某些 (低正则性) 函数类的收敛率. 例如, 回顾 Hölder 连续 (Hölder continuous) 函数空间  $C^{0,s}$ .

**定义 5.22:** 设  $s \in (0, 1]$  且  $\Omega \subseteq \mathbb{R}^d$ . 对  $f: \Omega \rightarrow \mathbb{R}$ , 定义

$$\|f\|_{C^{0,s}(\Omega)} := \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x})| + \sup_{\mathbf{x} \neq \mathbf{y} \in \Omega} \frac{|f(\mathbf{x}) - f(\mathbf{y})|}{\|\mathbf{x} - \mathbf{y}\|_2^s}, \quad (5.4.1)$$

并以  $C^{0,s}(\Omega)$  表示满足  $\|f\|_{C^{0,s}(\Omega)} < \infty$  的函数  $f \in C^0(\Omega)$  所组成的集合.

Hölder 连续函数可以由 cpwl 函数很好地逼近. 这导出下述结果.

**定理 5.23:** 设  $d \in \mathbb{N}$ . 则存在常数  $C = C(d) > 0$ , 并且对每个  $N \in \mathbb{N}$ , 存在参数为  $\mathbf{w} \in \mathbb{R}^N$  的 ReLU 神经网络  $\Phi_N(\mathbf{x}, \mathbf{w})$ , 使得

$$\text{size}(\Phi_N) = N, \quad \text{width}(\Phi_N) \leq N, \quad \text{depth}(\Phi_N) \leq C, \quad (5.4.2)$$

而且对每个  $s \in (0, 1]$  和  $f \in C^{0,s}([0, 1]^d)$ , 都有

$$\inf_{\mathbf{w} \in \mathbb{R}^N} \|f(\mathbf{x}) - \Phi_N(\mathbf{x}, \mathbf{w})\|_{C^0([0, 1]^d)} \leq C \|f\|_{C^{0,s}([0, 1]^d)} N^{-\frac{s}{d}}.$$

**证明:** 固定  $M \geq 2$ , 并考虑节点集合  $\{\boldsymbol{\nu}/M \mid \boldsymbol{\nu} \in \{-1, \dots, M+1\}^d\}$ , 其中  $\boldsymbol{\nu}/M = (\nu_1/M, \dots, \nu_d/M)$ . 这些节点自然给出把  $[-1/M, 1+1/M]^d$  划分为  $(2+M)^d$  个子超立方体的方法. 每个这样的子超立方体都可划分为  $d!$  个单纯形, 从而在  $[0, 1]^d$  上得到一个含  $d!(2+M)^d$  个单元的正则三角剖分  $\mathcal{T}$ . 由定理 5.14, 存在关于  $\mathcal{T}$  为 cpwl 的神经网络  $\Phi_N$ , 使得当  $\boldsymbol{\nu} \in \{0, \dots, M\}^d$  时  $\Phi_N^f(\boldsymbol{\nu}/M) = f(\boldsymbol{\nu}/M)$ , 并且在所有其他 (边界) 节点上  $\Phi_N^f(\boldsymbol{\nu}/M) = 0$ .

注意, 底层架构与  $f$  无关, 而且对某组依赖于  $f$  的参数  $\mathbf{w}_f$ , 可以写成  $\Phi_N^f(\mathbf{x}) = \Phi_N(\mathbf{x}, \mathbf{w}_f)$ . 为简化记号, 下文只写  $\Phi_N(\mathbf{x})$ . 有

$$\begin{aligned} \text{size}(\Phi_N) &=: N \leq C|\mathcal{T}| = Cd!(2+M)^d, \\ \text{width}(\Phi_N) &\leq N \leq C|\mathcal{T}| = Cd!(2+M)^d, \\ \text{depth}(\Phi_N) &\leq C, \end{aligned} \quad (5.4.3)$$

其中常数  $C$  仅依赖于  $d$  (因为对这里的正则三角剖分  $\mathcal{T}$ , 式 (5.3.2) 中的  $k_{\mathcal{T}}$  是一个仅依赖于  $d$  的固定常数). 这里还使用了宽度必然不超过规模这一事实.

下面估计误差. 固定一点  $\mathbf{x} \in [0, 1]^d$ . 则  $\mathbf{x}$  属于三角剖分的某个内部单纯形  $\tau$ . 该单纯形中任意两个节点之间的距离至多为

$$\left( \sum_{j=1}^d \left( \frac{1}{M} \right)^2 \right)^{1/2} = \frac{\sqrt{d}}{M} =: \varepsilon.$$

因为  $\Phi_N|_{\tau}$  是  $f$  在单纯形  $\tau$  的节点  $V(\tau)$  上的线性插值函数, 所以  $\Phi_N(\mathbf{x})$  是  $(f(\boldsymbol{\eta}))_{\boldsymbol{\eta} \in V(\tau)}$  的一个凸组合. 任取节点  $\boldsymbol{\eta}_0 \in V(\tau)$ . 则  $\|\mathbf{x} - \boldsymbol{\eta}_0\|_2 \leq \varepsilon$ , 且

$$\begin{aligned} |\Phi_N(\mathbf{x}) - \Phi_N(\boldsymbol{\eta}_0)| &\leq \max_{\boldsymbol{\eta}, \boldsymbol{\mu} \in V(\tau)} |f(\boldsymbol{\eta}) - f(\boldsymbol{\mu})| \\ &\leq \sup_{\substack{\mathbf{x}, \mathbf{y} \in [0, 1]^d \\ \|\mathbf{x} - \mathbf{y}\|_2 \leq \varepsilon}} |f(\mathbf{x}) - f(\mathbf{y})| \\ &\leq \|f\|_{C^{0,s}([0, 1]^d)} \varepsilon^s. \end{aligned}$$

因此, 利用  $f(\boldsymbol{\eta}_0) = \Phi_N(\boldsymbol{\eta}_0)$ , 得到

$$\begin{aligned} |f(\mathbf{x}) - \Phi_N(\mathbf{x})| &\leq |f(\mathbf{x}) - f(\boldsymbol{\eta}_0)| + |\Phi_N(\mathbf{x}) - \Phi_N(\boldsymbol{\eta}_0)| \\ &\leq 2\|f\|_{C^{0,s}([0, 1]^d)} \varepsilon^s \\ &= 2\|f\|_{C^{0,s}([0, 1]^d)} d^{\frac{s}{2}} M^{-s} \\ &= 2d^{\frac{s}{2}} \|f\|_{C^{0,s}([0, 1]^d)} (M^d)^{-\frac{s}{d}} \\ &\leq \tilde{C} N^{-\frac{s}{d}}, \end{aligned} \tag{5.4.4}$$

其中  $\tilde{C}$  仅依赖于  $d$ ; 这里使用了由式 (5.4.3) 得到的

$$N \leq Cd!(2 + M)^d \leq Cd!3^d M^d.$$

现在由式 (5.4.3) 和式 (5.4.4) 即得结论.  $\square$

**定理 5.23** 背后的原理还可以在更一般的情形下应用. 正则三角剖分上的每个 cpwl 函数都能由规模为  $O(N)$  的神经网络表示, 其中  $N$  表示单元数目; 因此, cpwl 函数的大多数经典逼近理论 (例如有限元逼近理论) 都可提升为 ReLU 逼近的结论. 例如, 众所周知, Sobolev 空间  $H^2([0, 1]^d)$  中的函数可由正则三角剖分上的 cpwl 函数在  $L^2([0, 1]^d)$  意义下以  $2/d$  的速率逼近; 例如见文献 [93, Chapter 22]. 与定理 5.23 的证明类似, 对每个  $N \in \mathbb{N}$ , 存在 ReLU 神经网络  $\Phi_N$ , 使得  $\text{size}(\Phi_N) = N$ , 并且对每个  $f \in H^2([0, 1]^d)$ ,

$$\inf_{\mathbf{w} \in \mathbb{R}^N} \|f - \Phi_N(\cdot, \mathbf{w})\|_{L^2([0, 1]^d)} \leq C\|f\|_{H^2([0, 1]^d)} N^{-\frac{2}{d}}.$$

最后, 可以考虑如何用 ReLU 神经网络逼近更光滑的函数, 例如  $f \in C^k([0, 1]^d)$ ,  $k > 1$ . 正如第 4 章针对 S 形激活函数所讨论的那样, 更大的  $k$  可以带来更快的收敛. 然而, 下一章将看到, 在正则三角剖分上模拟分段仿射函数, 并不会随着  $k$  增大而给出更好的逼近率. 为了利用 ReLU 网络中的这种光滑性, 第 7 章将首先构造模拟多项式的网络. 令人惊讶的是, 多项式可以由深层 ReLU 神经网络极其高效地逼近.

## 文献与延伸阅读

第 5.1 节引入的 ReLU 基本演算也见于文献 [236]. 每个 cpwl 函数都能表示成若干线性函数的最小值之最大值, 这一事实可追溯到文献 [304, 303]; 关于该结果的一种易读阐述, 另见文献 [231]. 此外, 文献 [320] 对这类表示所需的嵌套次数给出了更尖锐的界.

第 5.2 节的主要结果说明每个 cpwl 函数都能由 ReLU 网络表示, 它是上述事实的直接推论. 文献 [9] 最早观察到这一点, 并给出了网络规模界. 对满足局部凸条件的三角网格上的 cpwl 函数, 文献 [126] 显著改进了这些界. 在这一假设下, 网络规模实质上仅随片的数目线性增长. 文献 [189] 说明, 这一结论并不需要凸性假设. 第 5.3.2 节给出了类似结果, 其论证比文献 [189] 更简单. 第 5.3.3 节另行讨论了文献 [126] 中的局部凸情形, 因为它允许进一步改进某些常数.

第 5.4 节讨论的 Hölder 连续函数逼近结论来自 cpwl 函数的标准逼近理论; 例如可参见文献 [81], 或专注于 Sobolev 空间逼近的有限元文献 [66, 47, 93]. 此外, 文献 [334] 给出了更强的结果, 证明 ReLU 网络实质上可以达到定理 5.23 所得速率的两倍, 并且这一速率是尖锐的. 关于样条及分段多项式逼近的一般参考资料, 例如见文献 [279]. 最后, 其他激活函数也可得到类似的收敛结论; 例如见文献 [198].

## 习题

- 5.24. 设  $p: \mathbb{R} \rightarrow \mathbb{R}$  是次数为  $n \geq 1$  且首项系数非零的多项式,  $s: \mathbb{R} \rightarrow \mathbb{R}$  是连续的 S 形激活函数. 证明恒等映射  $x \mapsto x: \mathbb{R} \rightarrow \mathbb{R}$  属于  $\mathcal{N}_1^1(p; 1, n+1)$ , 但对任意  $L \in \mathbb{N}$ , 它都不属于  $\mathcal{N}_1^1(s; L)$ .
- 5.25. 考虑具有  $n \in \mathbb{N}_0$  个断点 (即函数不是  $C^1$  的点) 的 cpwl 函数  $f: \mathbb{R} \rightarrow \mathbb{R}$ . 确定用深度为 1 的 ReLU 神经网络精确表示每个这样的  $f$  所需的最小规模.
- 5.26. 证明仿射无关这一概念在点的置换下保持不变.
- 5.27. 设  $\tau = \text{co}(\mathbf{x}_0, \dots, \mathbf{x}_d)$  是一个  $d$ -单纯形. 证明: 对每个  $\mathbf{x} \in \tau$ , 满足  $\alpha_i \geq 0$ 、 $\sum_{i=0}^d \alpha_i = 1$  以及  $\mathbf{x} = \sum_{i=0}^d \alpha_i \mathbf{x}_i$  的系数  $\alpha_i$  是唯一的.
- 5.28. 设  $\tau = \text{co}(\boldsymbol{\eta}_0, \dots, \boldsymbol{\eta}_d)$  是一个  $d$ -单纯形. 证明  $\tau$  的边界为

$$\bigcup_{i=0}^d \text{co}(\{\boldsymbol{\eta}_0, \dots, \boldsymbol{\eta}_d\} \setminus \{\boldsymbol{\eta}_i\}).$$

# ReLU 神经网络的仿射片

前几章展示了浅层 ReLU 神经网络的一些卓越逼近结果. 然而在实践中, 更深的架构更为常见. 为理解其中原因, 本章讨论浅层 ReLU 网络相较于深层 ReLU 网络可能存在的若干不足.

研究 ReLU 神经网络局限性的一种传统而富有启发性的方法, 是分析这些函数能够生成的线性区域数量.

**定义 6.1:** 设  $d \in \mathbb{N}$ ,  $\Omega \subseteq \mathbb{R}^d$ , 且  $f: \Omega \rightarrow \mathbb{R}$  是连续分段线性函数 (见定义 5.5). 若  $p \in \mathbb{N}$  是满足下述条件的连通开集族  $(\Omega_i)_{i=1}^p$  的最小数目:

$$\bigcup_{i=1}^p \overline{\Omega_i} = \Omega, \quad f|_{\Omega_i} \text{ 对每个 } i = 1, \dots, p \text{ 都是仿射函数},$$

则称  $f$  有  $p$  个片 (或线性区域) (pieces (or linear regions)), 并记  $\text{Pieces}(f, \Omega) := p$ .

当  $d = 1$  时, 把  $f$  不可微的每一点称为  $f$  的断点 (break point).

为了得到函数的高精度连续分段线性逼近, 逼近函数必须具有许多片. 下一个定理对应于文献 [96, Theorem 2], 它量化了这一陈述.

**定理 6.2:** 设  $-\infty < a < b < \infty$ , 且  $f \in C^3([a, b])$  不是仿射函数. 则存在仅依赖于  $\int_a^b \sqrt{|f''(x)|} dx$  的常数  $C > 0$ , 使得对每个至多有  $p \in \mathbb{N}$  个片的连续分段线性函数  $g$ , 都有

$$\|g - f\|_{L^\infty([a, b])} > Cp^{-2}.$$

该定理的证明留作习题, 见习题 6.11.

定理 6.2 表明, 要用 ReLU 神经网络高精度逼近非线性函数, 就需要允许产生许多片的架构. 对于固定深度和宽度, 究竟能生成多少片? 第 6.1 节建立一个简单的理论上界; 随后, 第 6.2 节研究这些上界在何种条件下能够达到; 最后, 第 6.3 节考察“典型”神经网络具有多少片, 以讨论上述分析的实践意义. 令人意外的是, 随机初始化的深层神经网络平均拥有的片数远未接近理论上可达到的最大值.

## 6.1 上界

神经网络以神经元的复合与求和为基础. 这两种运算以非常特定的方式增加可能的片数, 图 6.1 展示了这两种运算及其效果. 具体如下:

- 求和: 设  $\Omega \subseteq \mathbb{R}$ . 两个连续分段线性函数  $f_1, f_2: \Omega \rightarrow \mathbb{R}$  之和满足

$$\text{Pieces}(f_1 + f_2, \Omega) \leq \text{Pieces}(f_1, \Omega) + \text{Pieces}(f_2, \Omega) - 1. \quad (6.1.1)$$



这是因为，在  $f_1$  与  $f_2$  都是仿射的每一点附近，它们的和也是仿射的。因而，和函数的断点数至多等于  $f_1$  与  $f_2$  的断点总数；而单变量函数的片数等于其断点数加一。

- 复合：仍设  $\Omega \subseteq \mathbb{R}$ . 两个函数  $f_1 : \mathbb{R}^d \rightarrow \mathbb{R}$  与  $f_2 : \Omega \rightarrow \mathbb{R}^d$  的复合满足

$$\text{Pieces}(f_1 \circ f_2, \Omega) \leq \text{Pieces}(f_1, \mathbb{R}^d) \text{Pieces}(f_2, \Omega). \quad (6.1.2)$$

事实上，对  $f_2$  的每个仿射片（把其中一个记为  $A \subseteq \mathbb{R}$ ）， $f_2$  在  $A$  上要么是常函数，要么是单射。若为常函数，则  $f_1 \circ f_2$  也是常函数；若为单射，则

$$\text{Pieces}(f_1 \circ f_2, A) = \text{Pieces}(f_1, f_2(A)) \leq \text{Pieces}(f_1, \mathbb{R}^d).$$

因为这一结论对  $f_2$  的每个片都成立，便得到式 (6.1.2)。




图 6.1: 上：两个连续分段线性函数的复合  $f_1 \circ f_2$  中，每当  $f_2$  的值穿过与  $f_1$  某个断点对应的水平时，都可能产生一个片。下：两个连续分段线性函数相加所得的  $f_1 + f_2$ ，可以在  $f_1$  或  $f_2$  的任一断点位置产生断点。

上述考察给出下面的结果，其论证沿用文献 [305, Lemma 2.1]. 我们对一般的连续分段线性激活函数陈述它；ReLU 激活函数对应于  $p = 2$ . 回忆记号  $(\sigma; d_0, \dots, d_{L+1})$  表示前馈神经网络的架构，见定义 2.1.

**定理 6.3:** 设  $L \in \mathbb{N}$ ，且  $\sigma$  是具有  $p$  个片的连续分段线性函数。考虑架构

$$(\sigma; 1, d_1, \dots, d_L, 1).$$

每个具有该架构的神经网络，其片数至多为

$$(p \text{width}(\Phi))^L.$$

**证明:** 对深度  $L$  作归纳. 设  $L = 1$ ，且  $\Phi : \mathbb{R} \rightarrow \mathbb{R}$  是架构为  $(\sigma; 1, d_1, 1)$  的神经网络. 则存在  $\mathbf{w}^{(0)}, \mathbf{w}^{(1)}, \mathbf{b}^{(0)} \in \mathbb{R}^{d_1}$  及  $b^{(1)} \in \mathbb{R}$ ，使得

$$\Phi(x) = \sum_{k=1}^{d_1} w_k^{(1)} \sigma(w_k^{(0)} x + b_k^{(0)}) + b^{(1)}, \quad x \in \mathbb{R}.$$

由式 (6.1.1)， $\text{Pieces}(\Phi) \leq p \text{width}(\Phi)$ .

对归纳步骤, 假设断言对  $L \in \mathbb{N}$  成立, 并设  $\Phi: \mathbb{R} \rightarrow \mathbb{R}$  是架构为  $(\sigma; 1, d_1, \dots, d_{L+1}, 1)$  的神经网络. 则可写成

$$\Phi(x) = \sum_{j=1}^{d_{L+1}} w_j \sigma(h_j(x)) + b, \quad x \in \mathbb{R},$$

其中  $\mathbf{w} \in \mathbb{R}^{d_{L+1}}$ 、 $b \in \mathbb{R}$ , 而每个  $h_j$  都是架构为  $(\sigma; 1, d_1, \dots, d_L, 1)$  的神经网络. 由归纳假设, 每个  $\sigma \circ h_\ell$  至多有  $p(\text{pwidth}(\Phi))^L$  个仿射片. 因而,  $\Phi$  至多有

$$\text{width}(\Phi) p(\text{pwidth}(\Phi))^L = (\text{pwidth}(\Phi))^{L+1}$$

个仿射片, 证明完毕.  $\square$

定理 6.3 说明, 给定架构能够生成的片数存在限制. 值得注意的是, 神经网络深度与宽度的作用截然不同: 增加宽度只能使片数按多项式增长, 而增加深度可以导致指数增长. 这是神经网络深度威力的第一个迹象.

为理解这一点对逼近问题的影响, 把定理 6.3 的界应用于定理 6.2.

**定理 6.4:** 设  $d_0 \in \mathbb{N}$ 、 $f \in C^3([0, 1]^{d_0})$ . 假设存在正长度线段  $\mathfrak{s} \subseteq [0, 1]^{d_0}$ , 使得

$$0 < c := \int_{\mathfrak{s}} \sqrt{|f''(x)|} \, dx.$$

则存在仅依赖于  $c$  的常数  $C > 0$ , 使得对每个具有  $L$  个隐藏层的 ReLU 神经网络  $\Phi: \mathbb{R}^{d_0} \rightarrow \mathbb{R}$ , 都有

$$\|f - \Phi\|_{L^\infty([0, 1]^{d_0})} \geq C(2\text{width}(\Phi))^{-2L}.$$

定理 6.4 给出了依赖于深度  $L$  的可达逼近率下界. 随着目标函数变得更光滑, 我们预期可以得到更快的收敛率 (比较第 4 章). 然而, 如果不增加深度, 似乎就无法利用这种额外的光滑性.

这一观察强烈表明, 更深的架构可能更优. 在把这一点说得更具体之前, 先探究定理 6.3 的上界是否也能达到.

## 6.2 上界的紧性

沿用文献 [305], 构造一个达到定理 6.3 上界的 ReLU 神经网络. 首先令  $h_1: [0, 1] \rightarrow \mathbb{R}$  为帽函数

$$h_1(x) := \begin{cases} 2x, & x \in [0, \frac{1}{2}], \\ 2 - 2x, & x \in [\frac{1}{2}, 1]. \end{cases}$$

这个函数可以由深度为一、含两个节点的 ReLU 神经网络表示:

$$h_1(x) = \sigma_{\text{ReLU}}(2x) - \sigma_{\text{ReLU}}(4x - 2), \quad x \in [0, 1]. \quad (6.2.1a)$$

递归定义

$$h_n := h_{n-1} \circ h_1, \quad n \geq 2. \quad (6.2.1b)$$

也就是说,  $h_n = h_1 \circ \cdots \circ h_1$  是  $h_1$  的  $n$  重复合. 因为  $h_1 : [0, 1] \rightarrow [0, 1]$ , 所以  $h_n : [0, 1] \rightarrow [0, 1]$ , 并且

$$h_n \in \mathcal{N}_1^1(\sigma_{\text{ReLU}}; n, 2).$$

这个函数具有颇有趣的行为: 它是一个含  $2^{n-1}$  个尖峰的“锯齿”函数, 见图 6.2.

**引理 6.5:** 设  $n \in \mathbb{N}$ . 对所有  $x \in [0, 1]$ , 都有

$$h_n(x) = \begin{cases} 2^n(x - i2^{-n}), & i \geq 0 \text{ 为偶数, 且 } x \in [i2^{-n}, (i+1)2^{-n}], \\ 2^n((i+1)2^{-n} - x), & i \geq 1 \text{ 为奇数, 且 } x \in [i2^{-n}, (i+1)2^{-n}]. \end{cases}$$

**证明:**  $n = 1$  的情形由定义成立. 现作归纳并假设断言对  $n$  成立. 设  $x \in [0, 1/2]$ , 并取偶数  $i \geq 0$  使得  $x \in [i2^{-(n+1)}, (i+1)2^{-(n+1)}]$ . 则  $2x \in [i2^{-n}, (i+1)2^{-n}]$ , 从而

$$h_n(h_1(x)) = h_n(2x) = 2^n(2x - i2^{-n}) = 2^{n+1}(x - i2^{-(n+1)}).$$

类似地, 若  $x \in [0, 1/2]$ , 且奇数  $i \geq 1$  满足  $x \in [i2^{-(n+1)}, (i+1)2^{-(n+1)}]$ , 则  $h_1(x) = 2x \in [i2^{-n}, (i+1)2^{-n}]$ , 并且

$$h_n(h_1(x)) = h_n(2x) = 2^n((i+1)2^{-n} - 2x) = 2^{n+1}((i+1)2^{-(n+1)} - x).$$

对  $x \in [1/2, 1]$ , 利用  $h_{n+1}$  关于  $1/2$  对称即可得到结论. □




图 6.2: 引理 6.5 中的函数  $h_n$ .

神经网络  $h_n$  的规模为  $O(n)$ , 并且至少在  $2^n$  个片上分段线性. 这说明片数确实可以随神经网络规模呈指数增长; 另见定理 6.3 中的上界.

### 6.3 实践中的片数

定理 6.3 表明, 深层神经网络能够比浅层神经网络具有多得多的片. 于是自然要问: 实践中的深层神经网络是否倾向于生成更多片? 更形式化地说, 随机初始化神经网络的权重时, 线性区域数的期望是多少? 它会随深度呈指数增长吗? 文献 [121] 分析了这一问题, 并令人意外地发现, 随机初始化神经网络的片数通常不随深度呈指数增长. 图 6.3




图 6.3: 两个随机初始化的神经网络  $\Phi_1$  与  $\Phi_2$ , 其架构分别为  $(\sigma_{\text{ReLU}}; 2, 10, 10, 1)$  和  $(\sigma_{\text{ReLU}}; 2, 5, 5, 5, 5, 5, 1)$ . 初始化方案采用 He 初始化 [127], 线性区域数分别为 114 和 110.

展示了两个按 He 初始化 [127] 随机初始化的神经网络, 一个浅而一个深. 两者的片数基本相同 (分别为 114 和 110), 从图中看不出哪个架构更深.

下面给出文献 [121] 主要结果的一个简化版本, 以说明为何随机深层神经网络常常表现得像浅层神经网络.

由图 6.1 可知, 复合两个函数  $f_1$  与  $f_2$  时, 如果  $f_2$  的值穿过与  $f_1$  某个断点对应的水平, 就会产生新的片. 对形如

$$\mathbf{x} \mapsto \sigma_{\text{ReLU}}(\langle \mathbf{a}, h(\mathbf{x}) \rangle + b)$$

的简单神经元, 其中  $h$  是连续分段线性函数、 $\mathbf{a}$  是向量、 $b$  是标量; 若  $\langle \mathbf{a}, h(\mathbf{x}) \rangle$  经常穿过  $-b$  水平, 就可能生成许多片.

若  $\mathbf{a}, b$  是随机变量, 并且已知  $h$  的振荡不太剧烈, 就可以量化  $\langle \mathbf{a}, h(\mathbf{x}) \rangle$  频繁穿过  $-b$  水平的概率. 下面来自文献 [157, Lemma 3.1] 的引理给出具体结论.

**引理 6.6:** 设  $c > 0$ , 且  $h: [0, c] \rightarrow \mathbb{R}$  是  $[0, c]$  上的连续分段线性函数. 设  $t \in \mathbb{N}$ 、 $A \subseteq \mathbb{R}$  是 Lebesgue 可测集, 并假设对每个  $y \in A$  都有

$$|\{x \in [0, c] \mid h(x) = y\}| \geq t.$$

则

$$c\|h'\|_{L^\infty} \geq \|h'\|_{L^1} \geq |A|t,$$

其中  $|A|$  是  $A$  的 Lebesgue 测度. 特别地, 若  $h$  至多有  $P \in \mathbb{N}$  个片且  $\|h'\|_{L^1} < \infty$ , 则对所有  $\delta > 0$  与  $t \leq P$ ,

$$\begin{aligned} \mathbb{P} \left[ |\{x \in [0, c] \mid h(x) = U\}| \geq t \right] &\leq \frac{\|h'\|_{L^1}}{\delta t}, \\ \mathbb{P} \left[ |\{x \in [0, c] \mid h(x) = U\}| > P \right] &= 0, \end{aligned}$$

其中  $U$  是区间  $[-\delta/2, \delta/2]$  上的均匀分布随机变量.

**证明：** 先假设  $c = 1$ ；一般情形可通过考察  $\tilde{h}(x) = h(x/c)$  得到。

取  $(c_i)_{i=1}^{P+1} \subseteq [0, 1]$ ，其中  $c_1 = 0$ 、 $c_{P+1} = 1$ ，且对  $i = 1, \dots, P+1$  有  $c_i \leq c_{i+1}$ ，使  $h$  的各片为  $((c_i, c_{i+1}))_{i=1}^P$ 。记

$$V_1 := [0, c_2], \quad V_i := (c_i, c_{i+1}], \quad i = 2, \dots, P,$$

并对  $i = 1, \dots, P+1$  定义

$$\tilde{V}_i := \bigcup_{j=1}^{i-1} V_j.$$

对  $n \in \mathbb{N} \cup \{\infty\}$  定义

$$T_{i,n} := h(V_i) \cap \left\{ y \in A \mid |\{x \in \tilde{V}_i \mid h(x) = y\}| = n - 1 \right\}.$$

换言之， $T_{i,n}$  包含在  $V_i$  上第  $n$  次取到的那些  $A$  中的值。因为  $h$  是连续分段线性的，对每个  $i = 1, \dots, P$  都有：

1. 当  $n_1, n_2 \in \mathbb{N} \cup \{\infty\}$  且  $n_1 \neq n_2$  时， $T_{i,n_1} \cap T_{i,n_2} = \emptyset$ ；
2.  $T_{i,\infty} \cup \bigcup_{n=1}^{\infty} T_{i,n} = h(V_i) \cap A$ ；
3. 对所有  $P < n < \infty$ ， $T_{i,n} = \emptyset$ ；
4.  $|T_{i,\infty}| = 0$ 。

注意，由于  $h$  在  $V_i$  上是仿射的，在  $V_i$  上有  $|h'| = |h(V_i)|/|V_i|$ 。因而，当  $t \leq P$  时，

$$\begin{aligned} \|h'\|_{L^1} &\geq \sum_{i=1}^P |h(V_i)| \geq \sum_{i=1}^P |h(V_i) \cap A| \\ &= \sum_{i=1}^P \left( \sum_{n=1}^{\infty} |T_{i,n}| + |T_{i,\infty}| \right) \\ &= \sum_{i=1}^P \sum_{n=1}^{\infty} |T_{i,n}| \geq \sum_{n=1}^t \sum_{i=1}^P |T_{i,n}|. \end{aligned}$$

第一个等号来自性质 1、2，第二个等号来自性质 4，最后一个不等式来自性质 3。按假设，对每个  $n \leq t$  及每个  $y \in A$ ，总有某个  $i \leq P$  使  $y \in T_{i,n}$  或  $y \in T_{i,\infty}$ 。因而由性质 4，

$$\sum_{i=1}^P |T_{i,n}| \geq |A|,$$

这就完成了证明。 □

把引理 6.6 应用于神经网络，其实质是：在单个神经元中，若偏置项从长度为  $\delta$  的区间上均匀随机选取，则通过复合生成至少  $t$  个片的概率与  $t$  成反比。

下面分析引理 6.6 如何导出随机初始化神经网络所生成片数的上界。为简化起见，只考虑随机偏置；不过，当偏置与权重都是随机变量时也有类似结果 [121]。

**定义 6.7:** 设  $L \in \mathbb{N}$ 、 $(d_0, d_1, \dots, d_L, 1) \in \mathbb{N}^{L+2}$ , 且对  $\ell = 0, \dots, L$  有  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ . 再设  $\delta > 0$ , 并令偏置向量  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$  ( $\ell = 0, \dots, L$ ) 为随机变量, 使每个  $\mathbf{b}^{(\ell)}$  的每个分量都独立地服从区间  $[-\delta/2, \delta/2]$  上的均匀分布. 称相应的 ReLU 神经网络为随机偏置神经网络 (random-bias neural network) .

为了把引理 6.6 应用于具有随机偏置的单个神经元, 还需要控制该神经元输入的导数.

**定义 6.8:** 设  $L \in \mathbb{N}$ 、 $(d_0, d_1, \dots, d_L, 1) \in \mathbb{N}^{L+2}$ , 并对  $\ell = 0, \dots, L$  设  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ 、 $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$ . 再设  $\delta > 0$ .

对  $\ell = 1, \dots, L+1$ 、 $i = 1, \dots, d_\ell$ , 引入函数

$$\eta_{\ell,i}(\mathbf{x}; (\mathbf{W}^{(j)}, \mathbf{b}^{(j)})_{j=0}^{\ell-1}) = (\mathbf{W}^{(\ell-1)} \mathbf{x}^{(\ell-1)})_i, \quad \mathbf{x} \in \mathbb{R}^{d_0},$$

其中  $\mathbf{x}^{(\ell-1)}$  如式 (2.1) 所定义. 称

$$\nu((\mathbf{W}^{(\ell)})_{\ell=1}^L, \delta) := \max \left\{ \left\| \eta'_{\ell,i}(\cdot; (\mathbf{W}^{(j)}, \mathbf{b}^{(j)})_{j=0}^{\ell-1}) \right\|_2 \left| \begin{array}{l} (\mathbf{b}^{(j)})_{j=0}^L \in \prod_{j=0}^L [-\delta/2, \delta/2]^{d_{j+1}}, \ell = 1, \dots, L, i = 1, \dots, d_\ell \end{array} \right. \right\}$$

为  $\Phi$  的最大内部导数 (maximal internal derivative) .

现在可以陈述本节的主要结果.

**定理 6.9:** 设  $L \in \mathbb{N}$ 、 $(d_0, d_1, \dots, d_L, 1) \in \mathbb{N}^{L+2}$ , 且  $\delta \in (0, 1]$ . 对  $\ell = 0, \dots, L$ , 设  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ , 并假设存在  $C_\nu > 0$  使得

$$\nu((\mathbf{W}^{(\ell)})_{\ell=0}^L, \delta) \leq C_\nu.$$

对相应的随机偏置神经网络  $\Phi$ , 以及  $\mathbb{R}^{d_0}$  中任意长度为 1 的线段  $\mathbf{s}$ , 都有

$$\mathbb{E}[\text{Pieces}(\Phi, \mathbf{s})] \leq 1 + d_1 + \frac{C_\nu}{\delta} (1 + (L-1) \ln(2 \text{width}(\Phi))) \sum_{j=2}^L d_j. \quad (6.3.1)$$

**证明:** 对  $\ell = 0, \dots, L$ , 设  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ ; 并令  $\mathbf{b}^{(\ell)} \in [-\delta/2, \delta/2]^{d_{\ell+1}}$  ( $\ell = 0, \dots, L$ ) 为均匀分布随机变量. 记

$$\begin{aligned} \theta_\ell : \mathbf{s} &\rightarrow \mathbb{R}^{d_\ell}, \\ \mathbf{x} &\mapsto (\eta_{\ell,i}(\mathbf{x}; (\mathbf{W}^{(j)}, \mathbf{b}^{(j)})_{j=0}^{\ell-1}))_{i=1}^{d_\ell}. \end{aligned}$$

设  $\kappa : \mathbf{s} \rightarrow [0, 1]$  是一个同构. 因为  $\theta_\ell$  的每个分量都是连续分段线性的, 所以存在点  $\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{q_\ell} \in \mathbf{s}$ , 其中  $\kappa(\mathbf{x}_j) < \kappa(\mathbf{x}_{j+1})$ , 使得  $\theta_\ell$  在每个区间  $[\kappa(\mathbf{x}_j), \kappa(\mathbf{x}_{j+1})]$ 、 $[0, \kappa(\mathbf{x}_0)]$  及  $[\kappa(\mathbf{x}_{q_\ell}), 1]$  上作为到  $\mathbb{R}^{d_\ell}$  的函数都是仿射的.

下面归纳地求  $q_\ell$  的上界. 当  $\ell = 2$  时,

$$\theta_2(\mathbf{x}) = \mathbf{W}^{(1)} \sigma_{\text{ReLU}}(\mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}).$$

因为  $\mathbf{W}^{(1)} \cdot + \mathbf{b}^{(1)}$  是仿射函数,  $\theta_2$  只能在  $\sigma_{\text{ReLU}}(\mathbf{W}^{(0)} \cdot + \mathbf{b}^{(0)})$  非仿射的点处非仿射; 这只可能发生在  $\mathbf{W}^{(0)} \cdot + \mathbf{b}^{(0)}$  的某个分量非平凡地穿过零时, 至多发生  $d_1$  次. 因而可取  $q_2 = d_1$ .

接着由  $q_\ell$  控制  $q_{\ell+1}$ . 注意

$$\theta_{\ell+1}(\mathbf{x}) = \mathbf{W}^{(\ell)} \sigma_{\text{ReLU}}(\theta_\ell(\mathbf{x}) + \mathbf{b}^{(\ell-1)}).$$

在  $\theta_\ell$  为仿射且所有坐标  $(\theta_\ell(\mathbf{x}) + \mathbf{b}^{(\ell-1)})_i \neq 0$  的每一点  $\mathbf{x} \in \mathfrak{s}$  附近,  $\theta_{\ell+1}$  都是仿射的. 因而可以选取  $q_{\ell+1}$ , 使得

$$q_{\ell+1} \leq q_\ell + |\{\mathbf{x} \in \mathfrak{s} \mid (\theta_\ell(\mathbf{x}) + \mathbf{b}^{(\ell-1)})_i = 0 \text{ 对至少一个 } i = 1, \dots, d_\ell\}|.$$

所以, 对  $\ell \geq 2$ ,

$$q_{\ell+1} \leq d_1 + \sum_{j=2}^{\ell} \sum_{i=1}^{d_j} |\{\mathbf{x} \in \mathfrak{s} \mid \eta_{j,i}(\mathbf{x}) = -\mathbf{b}_i^{(j)}\}|.$$

由定理 6.3,

$$\text{Pieces}(\eta_{\ell,i}(\cdot; (\mathbf{W}^{(j)}, \mathbf{b}^{(j)})_{j=0}^{\ell-1}), \mathfrak{s}) \leq (2\text{width}(\Phi))^{\ell-1}.$$

对  $k \in \mathbb{N} \cup \{\infty\}$  定义

$$p_{k,\ell,i} := \mathbb{P} \left[ |\{\mathbf{x} \in \mathfrak{s} \mid \eta_{\ell,i}(\mathbf{x}) = -\mathbf{b}_i^{(\ell)}\}| \geq k \right].$$

于是由引理 6.6,

$$p_{k,\ell,i} \leq \frac{C_\nu}{\delta k}, \quad p_{k,\ell,i} = 0 \quad \text{当 } k > (2\text{width}(\Phi))^{\ell-1}.$$

因而

$$\begin{aligned} & \mathbb{E} \left[ \sum_{j=2}^L \sum_{i=1}^{d_j} |\{\mathbf{x} \in \mathfrak{s} \mid \eta_{j,i}(\mathbf{x}) = -\mathbf{b}_i^{(j)}\}| \right] \\ & \leq \sum_{j=2}^L \sum_{i=1}^{d_j} \sum_{k=1}^{\infty} k \mathbb{P} \left[ |\{\mathbf{x} \in \mathfrak{s} \mid \eta_{j,i}(\mathbf{x}) = -\mathbf{b}_i^{(j)}\}| = k \right] \\ & \leq \sum_{j=2}^L \sum_{i=1}^{d_j} \sum_{k=1}^{\infty} k (p_{k,j,i} - p_{k+1,j,i}). \end{aligned}$$

内层和可估计为

$$\begin{aligned} \sum_{k=1}^{\infty} k (p_{k,j,i} - p_{k+1,j,i}) &= p_{1,j,i} + \sum_{k=2}^{\infty} p_{k,j,i} = \sum_{k=1}^{\infty} p_{k,j,i} \\ &\leq C_\nu \delta^{-1} \sum_{k=1}^{(2\text{width}(\Phi))^{L-1}} \frac{1}{k} \\ &\leq C_\nu \delta^{-1} \left( 1 + \int_1^{(2\text{width}(\Phi))^{L-1}} \frac{1}{x} dx \right) \\ &\leq C_\nu \delta^{-1} (1 + (L-1) \ln(2\text{width}(\Phi))). \end{aligned}$$



因此,  $q_{L+1}$  的期望可由

$$d_1 + C_\nu \delta^{-1} (1 + (L-1) \ln(2\text{width}(\Phi))) \sum_{j=2}^L d_j$$

控制. 最后, 因为  $\theta_L = \Phi_{L+1}|_s$ , 有

$$\text{Pieces}(\Phi, \mathfrak{s}) \leq q_{L+1} + 1,$$

从而得到结论. □

**注 6.10:** 对定理 6.9 有如下观察:

- 对深度的非指数依赖: 由式 (6.3.1) 可见, 片数的期望基本按  $O(LN)$  缩放, 其中  $N$  是该架构的神经元总数. 这说明片数的期望关于层数是线性的, 而定理 6.3 给出的上界则是指数型的.
- 最大内部导数: 定理 6.9 要求选择的权重使最大内部导数受某个数控制. 不过, 如果随机初始化权重的方式使最大内部导数以高概率被一个较小的数控制, 也可以证明类似结果. 实践中, 第  $\ell$  层的权重常按标准差为  $\sqrt{2/d_\ell}$  的中心正态分布初始化 [127]. 由于方差与层宽成反比, 内部导数以高概率保持有界, 并且与神经网络宽度无关. 这解释了图 6.3 中的观察.

◇

## 文献与延伸阅读

建立 ReLU 网络线性区域数的界, 是研究 ReLU 神经网络复杂度的一种常用工具, 见文献 [206, 253, 9, 283, 121]. 第 6.1 节给出的界基于文献 [305]. 第 6.2 节构造锯齿函数时沿用了文献 [305, 306] 的论证. 结合文献 [96] 中关于所需线性区域数的下界, 这一分析说明深度如何限制可达到的收敛率, 正如定理 6.4 所陈述的那样. 最后, 对随机初始化所得深层神经网络片数的分析 (第 6.3 节) 基于文献 [121, 157].

## 习题

## 习题

- 6.11.** 设  $-\infty < a < b < \infty$ , 且  $f \in C^3([a, b]) \setminus \mathbb{P}_1$ . 记  $p(\varepsilon) \in \mathbb{N}$  为把  $[a, b]$  划分成若干区间的最小区间数, 使得在这  $p(\varepsilon)$  个区间上定义的某个 (不必连续的) 分段线性函数能够在  $[a, b]$  上以误差  $\varepsilon > 0$  一致逼近  $f$ . 本题旨在证明

$$\liminf_{\varepsilon \searrow 0} p(\varepsilon) \sqrt{\varepsilon} > 0. \quad (6.3.2)$$

因而可以找到常数  $C > 0$ , 使所有  $\varepsilon > 0$  都满足  $\varepsilon \geq Cp(\varepsilon)^{-2}$ . 这给出了定理 6.2 的一个变体. 按以下步骤证明式 (6.3.2):

1. 固定  $\varepsilon > 0$ , 设  $a = x_0 < x_1 < \cdots < x_{p(\varepsilon)} = b$  是含  $p(\varepsilon)$  个片的一个划分. 对  $i = 0, \dots, p(\varepsilon) - 1$  及  $x \in [x_i, x_{i+1}]$ , 令

$$e_i(x) := f(x) - \left( f(x_i) + \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i} (x - x_i) \right).$$

证明: 对所有  $x \in [x_i, x_{i+1}]$ , 有  $|e_i(x)| \leq 2\varepsilon$ .

2. 令  $h_i := x_{i+1} - x_i$ ,  $m_i := (x_i + x_{i+1})/2$ , 证明

$$\max_{x \in [x_i, x_{i+1}]} |e_i(x)| = \frac{h_i^2}{8} |f''(m_i)| + O(h_i^3).$$

3. 假设  $c := \inf_{x \in [a, b]} |f''(x)| > 0$ , 证明

$$\liminf_{\varepsilon \searrow 0} p(\varepsilon) \sqrt{\varepsilon} \geq \frac{1}{4} \int_a^b \sqrt{|f''(x)|} dx.$$

4. 推出式 (6.3.2) 对一般的非线性函数  $f \in C^3([a, b])$  成立.

- 6.12.** 证明: 当  $L = 1$  时, 把仿射片数换成光滑片数后, 定理 6.3 对分段光滑函数仍成立. 光滑片数的定义, 是把定义 6.1 中的“仿射”换成“光滑” (即  $C^\infty$ ).

- 6.13.** 证明: 当  $L > 1$  时, 把仿射片数换成光滑片数后, 定理 6.3 对分段光滑函数不成立.

- 6.14.** 对  $p \in \mathbb{N}$ ,  $p > 2$  及  $n \in \mathbb{N}$ , 构造与式 (6.2.1) 中的  $h_n$  类似的函数  $h_n^{(p)}$ , 使得  $h_n^{(p)} \in \mathcal{N}_1^1(\sigma_{\text{ReLU}}; n, p)$ , 且  $h_n^{(p)}$  有  $p^n$  个片、规模为  $O(p^2 n)$ .

# 深层 ReLU 神经网络

上一章看到，若要让 ReLU 神经网络以较高速率逼近光滑函数，较多层数是必要的前提。现在分析，要取得良好的光滑函数逼近率，多大的深度便已足够。

在第 4 章中，高效逼近光滑函数的主要工具之一，是重建高阶 B 样条等基于多项式的函数。对光滑激活函数，可以利用其非线性复现多项式；这一论证显然无法照搬到分段线性的 ReLU 上。另一方面，我们已经看到，深层 ReLU 神经网络能极其高效地产生引理 6.5 所讨论的强振荡锯齿函数。本章的核心观察是，锯齿函数与平方函数密切相关，而平方函数又通向多项式。Dmitry Yarotsky 于 2016 年首次提出这一观察 [332]，本章主要以该论文为基础。

第 7.1、7.2 节给出 Yarotsky 对平方函数与乘法函数的逼近。由此直接推出，第 7.3 节中的深层 ReLU 神经网络在逼近解析函数时可以比浅层网络高效得多。利用这些工具，第 7.4 节最终说明，深层 ReLU 神经网络能高效逼近导数为 Hölder 连续的  $k$  次连续可微函数。

## 7.1 平方函数

先逼近映射  $x \mapsto x^2$ 。这一构造最早见于文献 [332]，它以式 (6.2.1) 定义、最初由文献 [305] 引入的锯齿函数  $h_n$  为基础，另见图 6.2。图 7.1 展示了证明思路。




图 7.1: 命题 7.1 中  $s_n$  的构造.

**命题 7.1:** 设  $n \in \mathbb{N}$ . 则

$$s_n(x) := x - \sum_{j=1}^n \frac{h_j(x)}{2^{2j}}$$

是  $[0, 1]$  上的分段线性函数，其断点为  $x_{n,j} = j2^{-n}$ ,  $j = 0, \dots, 2^n$ . 此外，对每个  $k = 0, \dots, 2^n$  都有  $s_n(x_{n,k}) = x_{n,k}^2$ ；也就是说， $s_n$  是  $x^2$  在  $[0, 1]$  上的分段线性插值函数。

**证明：**  $n = 1$  时断言成立. 现作归纳, 假设断言对  $s_n$  成立, 并取  $k \in \{0, \dots, 2^{n+1}\}$ . 由引理 6.5, 当  $k$  为偶数时,  $h_{n+1}(x_{n+1,k}) = 0$ . 因而, 对所有偶数  $k \in \{0, \dots, 2^{n+1}\}$ ,

$$\begin{aligned} s_{n+1}(x_{n+1,k}) &= x_{n+1,k} - \sum_{j=1}^{n+1} \frac{h_j(x_{n+1,k})}{2^{2j}} \\ &= s_n(x_{n+1,k}) - \frac{h_{n+1}(x_{n+1,k})}{2^{2(n+1)}} = s_n(x_{n+1,k}) = x_{n+1,k}^2, \end{aligned}$$

这里使用了归纳假设, 因为  $x_{n+1,k} = k2^{-(n+1)} = (k/2)2^{-n} = x_{n,k/2}$ .

现设  $k \in \{1, \dots, 2^{n+1} - 1\}$  为奇数. 由引理 6.5,  $h_{n+1}(x_{n+1,k}) = 1$ . 又因为  $s_n$  在

$$[x_{n,(k-1)/2}, x_{n,(k+1)/2}] = [x_{n+1,k-1}, x_{n+1,k+1}]$$

上是线性的, 而  $x_{n+1,k}$  是该区间的中点, 所以

$$\begin{aligned} s_{n+1}(x_{n+1,k}) &= s_n(x_{n+1,k}) - \frac{h_{n+1}(x_{n+1,k})}{2^{2(n+1)}} \\ &= \frac{1}{2}(x_{n+1,k-1}^2 + x_{n+1,k+1}^2) - \frac{1}{2^{2(n+1)}} \\ &= \frac{(k-1)^2}{2^{2(n+1)+1}} + \frac{(k+1)^2}{2^{2(n+1)+1}} - \frac{2}{2^{2(n+1)+1}} \\ &= \frac{1}{2} \frac{2k^2}{2^{2(n+1)}} = \frac{k^2}{2^{2(n+1)}} = x_{n+1,k}^2. \end{aligned}$$

证明完毕. □

由此得到下面的结论 [332, Proposition 2].

**引理 7.2：** 对  $n \in \mathbb{N}$ , 有

$$\sup_{x \in [0,1]} |x^2 - s_n(x)| \leq 2^{-2n-1}.$$

此外,  $s_n \in \mathcal{N}_1^1(\sigma_{\text{ReLU}}; n, 3)$ , 并且  $\text{size}(s_n) \leq 7n$ 、 $\text{depth}(s_n) = n$ .

**证明：** 令  $e_n(x) := x^2 - s_n(x)$ . 取  $x$  位于长度为  $2^{-n}$  的区间  $[x_{n,k}, x_{n,k+1}] = [k2^{-n}, (k+1)2^{-n}]$  内. 因为  $s_n$  是  $x^2$  在该区间上的线性插值函数,

$$|e'_n(x)| = \left| 2x - \frac{x_{n,k+1}^2 - x_{n,k}^2}{2^{-n}} \right| = \left| 2x - \frac{2k+1}{2^n} \right| \leq \frac{1}{2^n}.$$

因而  $e_n : [0, 1] \rightarrow \mathbb{R}$  的 Lipschitz 常数为  $2^{-n}$ . 又因所有  $k = 0, \dots, 2^n$  都满足  $e_n(x_{n,k}) = 0$ , 且  $[x_{n,k}, x_{n,k+1}]$  的长度为  $2^{-n}$ , 故

$$\sup_{x \in [0,1]} |e_n(x)| \leq \frac{1}{2}, 2^{-n} 2^{-n} = 2^{-2n-1}.$$

最后说明  $s_n$  能由所述架构的神经网络表示. 当  $n \geq 2$  时,

$$\begin{aligned} s_n(x) &= x - \sum_{j=1}^n \frac{h_j(x)}{2^{2j}} = s_{n-1}(x) - \frac{h_n(x)}{2^{2n}} \\ &= \sigma_{\text{ReLU}} \circ s_{n-1}(x) - \frac{h_1 \circ h_{n-1}(x)}{2^{2n}}. \end{aligned}$$

这里用到  $s_{n-1}$  是  $x^2$  的分段线性插值函数, 故对所有  $x \in [0, 1]$ ,  $s_{n-1}(x) \geq 0$  且  $s_{n-1}(x) = \sigma_{\text{ReLU}}(s_{n-1}(x))$ . 因而  $s_n$  的深度为  $n$ 、宽度为 3, 见图 7.2.  $\square$




图 7.2: 神经网络  $h_1(x) = \sigma_{\text{ReLU}}(2x) - \sigma_{\text{ReLU}}(4x-2)$  与  $s_n(x) = \sigma_{\text{ReLU}}(s_{n-1}(x)) - h_n(x)/2^{2n}$ , 其中  $h_n = h_1 \circ h_{n-1}$ . 本图基于文献 [332, Fig. 2c] 与文献 [280, Fig. 1a].

总之, 已经证明  $s_n : [0, 1] \rightarrow [0, 1]$  在  $[0, 1]$  上一致逼近平方函数, 且误差随神经网络规模呈指数下降. 注意, 由定理 6.4, 浅层神经网络不可能做到这一点: 它至多只能由关于网络规模呈多项式增长的片数所构成的  $[0, 1]$  划分上插值  $x^2$ .

## 7.2 乘法

由引理 7.2 可知, 深度有助于逼近  $x \mapsto x^2$ ; 乍看之下, 这似乎只是一个很特殊的例子. 然而, 这为快速逼近高正则性函数 (例如某个  $k > 1$  下的  $C^k([0, 1]^d)$  函数) 开辟了道路. 关键观察是, 借助极化恒等式, 可以把两数之积写成平方之和:

$$xy = \frac{(x+y)^2 - (x-y)^2}{4}, \quad (7.2.1)$$

对所有  $x, y \in \mathbb{R}$  成立. 高效逼近乘法运算便能高效逼近多项式, 而多项式是具有  $k \in \mathbb{N}$  阶导数的函数的著名逼近工具. 在下一节进一步探索这一思路之前, 先精确表述神经网络能够高效逼近实数乘法这一观察.

先考察两个数的乘法; 此时, 关于目标精度只需对数规模的神经网络 [332, Proposition 3].

**引理 7.3:** 对每个  $\varepsilon > 0$ , 存在 ReLU 神经网络  $\Phi_\varepsilon^\times : [-1, 1]^2 \rightarrow [-1, 1]$ , 使得

$$\sup_{x, y \in [-1, 1]} |xy - \Phi_\varepsilon^\times(x, y)| \leq \varepsilon.$$

此外, 存在与  $\varepsilon$  无关的常数  $C > 0$ , 使得

$$\text{size}(\Phi_\varepsilon^\times) \leq C(1 + |\log \varepsilon|), \quad \text{depth}(\Phi_\varepsilon^\times) \leq C(1 + |\log \varepsilon|).$$

若  $x = 0$  或  $y = 0$ , 则  $\Phi_\varepsilon^\times(x, y) = 0$ .

**证明:** 令  $n = \lceil |\log_4 \varepsilon| \rceil$ , 并定义神经网络

$$\begin{aligned} \Phi_\varepsilon^\times(x, y) := & s_n \left( \frac{\sigma_{\text{ReLU}}(x+y) + \sigma_{\text{ReLU}}(-x-y)}{2} \right) \\ & - s_n \left( \frac{\sigma_{\text{ReLU}}(x-y) + \sigma_{\text{ReLU}}(y-x)}{2} \right). \end{aligned} \quad (7.2.2)$$

因为  $|a| = \sigma_{\text{ReLU}}(a) + \sigma_{\text{ReLU}}(-a)$ , 由式 (7.2.1), 对所有  $x, y \in [-1, 1]$ ,

$$\begin{aligned} |xy - \Phi_\varepsilon^\times(x, y)| &= \left| \frac{(x+y)^2 - (x-y)^2}{4} - \left( s_n\left(\frac{|x+y|}{2}\right) - s_n\left(\frac{|x-y|}{2}\right) \right) \right| \\ &= \left| \frac{4((x+y)/2)^2 - 4((x-y)/2)^2}{4} - \frac{4s_n(|x+y|/2) - 4s_n(|x-y|/2)}{4} \right| \\ &\leq \frac{4(2^{-2n-1} + 2^{-2n-1})}{4} = 4^{-n} \leq \varepsilon, \end{aligned}$$

其中使用了  $|x+y|/2, |x-y|/2 \in [0, 1]$ . 又有

$$\begin{aligned} \text{depth}(\Phi_\varepsilon^\times) &= 1 + \text{depth}(s_n) = 1 + n \leq 1 + \lceil \log_4 \varepsilon \rceil, \\ \text{size}(\Phi_\varepsilon^\times) &\leq C + 2\text{size}(s_n) \leq Cn \leq C(1 - \log \varepsilon), \end{aligned}$$

其中  $C > 0$  为某个常数.

由式 (7.2.2) 及  $s_n : [0, 1] \rightarrow [0, 1]$ , 可知  $\Phi_\varepsilon^\times$  映射  $[-1, 1]^2$  到  $[-1, 1]$ . 最后, 若  $x = 0$ , 则

$$\Phi_\varepsilon^\times(x, y) = s_n(|x+y|) - s_n(|x-y|) = s_n(|y|) - s_n(|y|) = 0.$$

$y = 0$  时论证相同. □

与命题 4.8 和引理 5.11 类似, 可以把双输入运算组织成二叉树, 从而推广到任意多个输入; 另见文献 [332], 以及针对这里所用论证的文献 [280, Proposition 3.3].

**命题 7.4:** 对每个  $n \geq 2$  及  $\varepsilon > 0$ , 存在 ReLU 神经网络  $\Phi_{n,\varepsilon}^\times : [-1, 1]^n \rightarrow [-1, 1]$ , 使得

$$\sup_{x_j \in [-1, 1]} \left| \prod_{j=1}^n x_j - \Phi_{n,\varepsilon}^\times(x_1, \dots, x_n) \right| \leq \varepsilon.$$

此外, 存在与  $\varepsilon, n$  无关的常数  $C > 0$ , 使得

$$\begin{aligned} \text{size}(\Phi_{n,\varepsilon}^\times) &\leq Cn(1 + |\log(\varepsilon/n)|), \\ \text{depth}(\Phi_{n,\varepsilon}^\times) &\leq C \log(n)(1 + |\log(\varepsilon/n)|). \end{aligned}$$

**证明:** 先考虑  $n = 2^k$ . 当  $k = 1$  时, 令  $\tilde{\Phi}_{2,\delta}^\times := \Phi_\delta^\times$ . 当  $k \geq 2$  时, 令

$$\tilde{\Phi}_{2^k,\delta}^\times := \Phi_\delta^\times \circ (\tilde{\Phi}_{2^{k-1},\delta}^\times, \tilde{\Phi}_{2^{k-1},\delta}^\times).$$

由引理 7.3, 该神经网络的深度满足

$$\text{depth}(\tilde{\Phi}_{2^k,\delta}^\times) \leq k \text{depth}(\Phi_\delta^\times) \leq Ck(1 + |\log \delta|) \leq C \log(n)(1 + |\log \delta|).$$

注意  $\Phi_\delta^\times$  出现的次数为  $\sum_{j=0}^{k-1} 2^j \leq n$ , 故  $\tilde{\Phi}_{2^k,\delta}^\times$  的规模至多为  $Cn \text{size}(\Phi_\delta^\times) \leq Cn(1 + |\log \delta|)$ .

为估计逼近误差, 记  $\mathbf{x} = (x_j)_{j=1}^{2^k}$ , 并令

$$e_k := \sup_{x_j \in [-1,1]} \left| \prod_{j \leq 2^k} x_j - \tilde{\Phi}_{2^k, \delta}^\times(\mathbf{x}) \right|.$$

使用简记  $\mathbf{x}_{\leq 2^{k-1}} := (x_1, \dots, x_{2^{k-1}})$ , 得到

$$\begin{aligned} e_k &= \sup_{x_j \in [-1,1]} \left| \prod_{j=1}^{2^k} x_j - \Phi_\delta^\times \left( \tilde{\Phi}_{2^{k-1}, \delta}^\times(\mathbf{x}_{\leq 2^{k-1}}), \tilde{\Phi}_{2^{k-1}, \delta}^\times(\mathbf{x}_{> 2^{k-1}}) \right) \right| \\ &\leq \delta + \sup_{x_j \in [-1,1]} \left( \left| \prod_{j \leq 2^{k-1}} x_j \right| e_{k-1} + \left| \tilde{\Phi}_{2^{k-1}, \delta}^\times(\mathbf{x}_{> 2^{k-1}}) \right| e_{k-1} \right) \\ &\leq \delta + 2e_{k-1} \leq \delta + 2(\delta + 2e_{k-2}) \leq \dots \leq \delta \sum_{j=0}^{k-2} 2^j + 2^{k-1}e_1 \\ &\leq 2^k \delta = n\delta. \end{aligned}$$

这里使用了  $e_1 \leq \delta$ , 以及  $\tilde{\Phi}_{2^{k-1}, \delta}^\times$  把  $[-1, 1]^{2^{k-1}}$  映入  $[-1, 1]$ ; 后者由引理 7.3 得到.

对一般的  $n \geq 2$  (不必为  $2^k$ ), 与引理 5.11 类似, 用恒等神经网络替换其中一些  $\Phi_\delta^\times$  即可. 最后令  $\delta := \varepsilon/n$ 、 $\Phi_{n, \varepsilon}^\times := \tilde{\Phi}_{n, \delta}^\times$ , 便完成证明.  $\square$

### 7.3 多项式、解析函数与深度分离

下面讨论上述观察的若干初步推论, 先从一元多项式

$$p(x) = \sum_{j=0}^n c_j x^j \tag{7.3.1}$$

的逼近开始. 一种方法是使用 Horner 格式及引理 7.3 中的近似乘法  $\Phi_\varepsilon^\times$ :

$$\begin{aligned} p(x) &= c_0 + x(c_1 + x(\dots + x c_n) \dots), \\ &\simeq c_0 + \Phi_\varepsilon^\times(x, c_1 + \Phi_\varepsilon^\times(x, c_2 + \dots + \Phi_\varepsilon^\times(x, c_n)) \dots). \end{aligned}$$

由于乘法嵌套, 这一格式需要  $O(n)$  的深度. 另一种方法是用近似乘法  $\Phi_\varepsilon^\times$  构成二叉树, 同时逼近所有单项式  $1, x, \dots, x^n$ , 再在输出层将它们组合, 见图 7.3. 这一思路给出规模  $O(n \log n)$ 、深度  $O(\log n)$  的网络. 下述引理形式化了这一点, 见文献 [236, Lemma A.5]、[90, Proposition III.5], 尤其是文献 [227, Lemma 4.3]. 证明留作习题 7.14.

**引理 7.5:** 存在常数  $C > 0$ , 使得对任意  $\varepsilon \in (0, 1)$  及式 (7.3.1) 中次数  $n \geq 2$  的任意多项式  $p$ , 都存在神经网络  $\Phi_\varepsilon^p$  满足

$$\sup_{x \in [-1, 1]} |p(x) - \Phi_\varepsilon^p(x)| \leq C\varepsilon \sum_{j=0}^n |c_j|,$$

且

$$\text{size}(\Phi_\varepsilon^p) \leq Cn \log(n/\varepsilon), \quad \text{depth}(\Phi_\varepsilon^p) \leq C \log(n/\varepsilon).$$






图 7.3: 当  $n = 2^k$  时, 可以用深度为  $k$  的二叉树生成单项式  $1, \dots, x^n$ . 每个节点表示其输入之积, 单输入节点解释为平方.

引理 7.5 说明深层 ReLU 网络能够高效逼近多项式. 这对解析函数 (analytic function) 有一个有趣推论: 若  $f : [-1, 1] \rightarrow \mathbb{R}$  在任意点  $x \in [-1, 1]$  附近都等于其以  $x$  为中心的 Taylor 级数, 则称  $f$  为解析函数. 例如, 所有多项式以及  $\sin$ 、 $\cos$ 、 $\exp$  等都是解析函数. 有如下结果 [88, 228].

**命题 7.6:** 设  $f : [-1, 1] \rightarrow \mathbb{R}$  是非线性的解析函数. 则存在常数  $C, \beta > 0$ , 使得对每个  $N \in \mathbb{N}$ , 都存在 ReLU 神经网络  $\Phi_N$ , 满足

$$\text{size}(\Phi_N) \leq N, \quad \text{depth}(\Phi_N) \leq C\sqrt{N},$$

且

$$\sup_{x \in [-1, 1]} |f(x) - \Phi_N(x)| \leq C \exp(-\beta\sqrt{N}).$$

**证明:** 证明深层神经网络的上界. 先假设  $f$  在 0 附近的 Taylor 级数收敛半径为  $r > 1$ . 则对所有  $x \in [-1, 1]$ ,

$$f(x) = \sum_{j \in \mathbb{N}_0} c_j x^j, \quad c_j = \frac{f^{(j)}(0)}{j!}, \quad |c_j| \leq C_r r^{-j},$$

其中最后一个不等式对所有  $j \in \mathbb{N}_0$  成立,  $C_r > 0$  为某个常数. 因而  $p_n(x) := \sum_{j=0}^n c_j x^j$  满足

$$\sup_{x \in [-1, 1]} |f(x) - p_n(x)| \leq \sum_{j > n} |c_j| \leq C_r \sum_{j > n} r^{-j} \leq \frac{C_r r^{-n}}{1 - r^{-1}}.$$

固定  $\varepsilon := r^{-n}$ , 并令  $\Phi_\varepsilon^{p_n}$  为引理 7.5 中的网络. 则

$$\begin{aligned} \sup_{x \in [-1, 1]} |f(x) - \Phi_\varepsilon^{p_n}(x)| &\leq \sup_{x \in [-1, 1]} (|f(x) - p_n(x)| + |p_n(x) - \Phi_\varepsilon^{p_n}(x)|) \\ &\leq \left( \frac{C_r}{1 - r^{-1}} + C \sum_{j \in \mathbb{N}_0} |c_j| \right) r^{-n} = \tilde{C} r^{-n}, \end{aligned}$$

其中  $\tilde{C}$  依赖于  $r$ 、 $C_r$  及引理 7.5 中的常数, 但与  $n$  无关. 由该引理,

$$\begin{aligned} \text{size}(\Phi_\varepsilon^{p_n}) &\leq \hat{C} n (\log n + n \log r) = O(n^2), \\ \text{depth}(\Phi_\varepsilon^{p_n}) &\leq \hat{C} (\log n + n \log r) = O(n). \end{aligned}$$

取  $N = \lceil Cn(\log n + n \log r) \rceil$ , 便有  $\text{size}(\Phi_\varepsilon^{p_n}) \leq N$ 、 $\text{depth}(\Phi_\varepsilon^{p_n}) = O(\sqrt{N})$ , 且

$$\sup_{x \in [-1, 1]} |f(x) - \Phi_\varepsilon^{p_n}(x)| \leq \tilde{C} \exp(-\log(r)n) \leq \tilde{C} \exp(-\beta n),$$

其中  $\beta$  依赖于  $\log r$  和上述常数. 因  $n \in \mathbb{N}$  任意, 断言成立.

Taylor 展开仅局部收敛的一般情形留作习题 7.15.  $\square$

**注 7.7:** 上述多项式与解析函数逼近的讨论可推广到多元情形. 下一小节的证明会讨论多项式; 关于 ReLU 网络逼近多元多项式的更明确陈述, 见文献 [228, Section 2.3]. 对解析函数  $f: [-1, 1]^d \rightarrow \mathbb{R}$ , 由此得到形如  $\exp(-\beta N^{1/(1+d)})$  的误差界, 见文献 [88, 228].  $\diamond$

上述命题展示了解析函数逼近中的一种指数收敛. 另一方面, 定理 6.4 已经说明, 固定深度的网络一般只能达到代数收敛率. 这导出一个关于深层 ReLU 架构在逼近非线性解析函数时更优的显著结论: 与深层架构所需规模相比, 固定深度网络的参数数量必须比任意多项式增长得更快. 下述推论将这一观察形式化.

**推论 7.8:** 设  $f: [-1, 1] \rightarrow \mathbb{R}$  是非线性的解析函数. 则存在常数  $C, \beta > 0$ , 使得对每个  $\varepsilon > 0$ , 都存在 ReLU 神经网络  $\Phi_{\text{deep}}$  满足

$$\sup_{x \in [-1, 1]} |f(x) - \Phi_{\text{deep}}(x)| \leq C \exp(-\beta \sqrt{\text{size}(\Phi_{\text{deep}})}) \leq \varepsilon, \quad (7.3.2)$$

而对任意深度至多为  $L$  的 ReLU 神经网络  $\Phi_{\text{shallow}}$ , 都有

$$\sup_{x \in [-1, 1]} |f(x) - \Phi_{\text{shallow}}(x)| \geq C^{-1} \text{size}(\Phi_{\text{shallow}})^{-2L}. \quad (7.3.3)$$

**证明:** 式 (7.3.2) 中的上界是命题 7.6 的直接推论; 式 (7.3.3) 中的下界由定理 6.4 得到.  $\square$

该命题说明, 对某些非常重要的函数, 使用浅层架构而非深层架构逼近时需要显著更多的参数. 这类陈述称为深度分离 (depth separation) 结果. 例如, 文献 [305, 306, 308] 利用第 6.2 节构造的锯齿函数证明了这类结果. 文献 [184, 332] 也给出了与推论 7.8 精神相近的逼近下界.

## 7.4 $C^{k,s}$ 函数

下面讨论前几节的观察对  $C^{k,s}$  类函数逼近的意义.

**定义 7.9:** 设  $k \in \mathbb{N}_0$ 、 $s \in [0, 1]$ 、 $\Omega \subseteq \mathbb{R}^d$ . 对  $f: \Omega \rightarrow \mathbb{R}$  定义

$$\begin{aligned} \|f\|_{C^{k,s}(\Omega)} := & \sup_{\mathbf{x} \in \Omega} \max_{\{\boldsymbol{\alpha} \in \mathbb{N}_0^d \mid |\boldsymbol{\alpha}| \leq k\}} |D^{\boldsymbol{\alpha}} f(\mathbf{x})| \\ & + \sup_{\mathbf{x} \neq \mathbf{y} \in \Omega} \max_{\{\boldsymbol{\alpha} \in \mathbb{N}_0^d \mid |\boldsymbol{\alpha}| = k\}} \frac{|D^{\boldsymbol{\alpha}} f(\mathbf{x}) - D^{\boldsymbol{\alpha}} f(\mathbf{y})|}{\|\mathbf{x} - \mathbf{y}\|^s}. \end{aligned} \quad (7.4.1)$$

以  $C^{k,s}(\Omega)$  表示所有满足  $f \in C^k(\Omega)$  且  $\|f\|_{C^{k,s}(\Omega)} < \infty$  的函数.

注意, 对所有  $0 < s \leq t \leq 1$ , 这些空间按如下关系排列:

$$C^k(\Omega) \supseteq C^{k,s}(\Omega) \supseteq C^{k,t}(\Omega) \supseteq C^{k+1}(\Omega).$$

为陈述主要结果, 先回顾  $C^{k,s}(\Omega)$  函数的 Taylor 余项公式的一种版本.

**引理 7.10:** 设  $d \in \mathbb{N}$ ,  $k \in \mathbb{N}$ ,  $s \in [0, 1]$ ,  $\Omega = [0, 1]^d$ , 且  $f \in C^{k,s}(\Omega)$ . 则对所有  $\mathbf{a}, \mathbf{x} \in \Omega$ ,

$$f(\mathbf{x}) = \sum_{\{\alpha \in \mathbb{N}_0^d \mid 0 \leq |\alpha| \leq k\}} \frac{D^\alpha f(\mathbf{a})}{\alpha!} (\mathbf{x} - \mathbf{a})^\alpha + R_k(\mathbf{x}), \quad (7.4.2)$$

而且, 若  $h := \max_{i \leq d} |a_i - x_i|$ , 则

$$|R_k(\mathbf{x})| \leq h^{k+s} \frac{d^{k+1/2}}{k!} \|f\|_{C^{k,s}(\Omega)}.$$

**证明:** 首先, 对函数  $g \in C^k(\mathbb{R})$  及  $a, t \in \mathbb{R}$ , 存在介于  $a$  与  $t$  之间的  $\xi$ , 使得

$$\begin{aligned} g(t) &= \sum_{j=0}^{k-1} \frac{g^{(j)}(a)}{j!} (t-a)^j + \frac{g^{(k)}(\xi)}{k!} (t-a)^k \\ &= \sum_{j=0}^k \frac{g^{(j)}(a)}{j!} (t-a)^j + \frac{g^{(k)}(\xi) - g^{(k)}(a)}{k!} (t-a)^k. \end{aligned}$$

现设  $f \in C^{k,s}(\mathbb{R}^d)$ ,  $\mathbf{a}, \mathbf{x} \in \mathbb{R}^d$ , 并令  $g(t) := f(\mathbf{a} + t(\mathbf{x} - \mathbf{a}))$ . 对  $f(\mathbf{x}) = g(1)$  有

$$f(\mathbf{x}) = \sum_{j=0}^{k-1} \frac{g^{(j)}(0)}{j!} + \frac{g^{(k)}(\xi)}{k!}.$$

由链式法则,

$$g^{(j)}(t) = \sum_{\{\alpha \in \mathbb{N}_0^d \mid |\alpha|=j\}} \binom{j}{\alpha} D^\alpha f(\mathbf{a} + t(\mathbf{x} - \mathbf{a})) (\mathbf{x} - \mathbf{a})^\alpha,$$

其中使用多重指标记号

$$\binom{j}{\alpha} = \frac{j!}{\alpha!} = \frac{j!}{\prod_{r=1}^d \alpha_r!}, \quad (\mathbf{x} - \mathbf{a})^\alpha = \prod_{r=1}^d (x_r - a_r)^{\alpha_r}.$$

因而, 对某个  $\xi \in [0, 1]$ ,

$$\begin{aligned} f(\mathbf{x}) &= \underbrace{\sum_{\{\alpha \in \mathbb{N}_0^d \mid 0 \leq |\alpha| \leq k\}} \frac{D^\alpha f(\mathbf{a})}{\alpha!} (\mathbf{x} - \mathbf{a})^\alpha}_{\in \mathbb{P}_k} \\ &\quad + \underbrace{\sum_{|\alpha|=k} \frac{D^\alpha f(\mathbf{a} + \xi(\mathbf{x} - \mathbf{a})) - D^\alpha f(\mathbf{a})}{\alpha!} (\mathbf{x} - \mathbf{a})^\alpha}_{=: R_k}. \end{aligned}$$

利用  $h$  的定义, 可估计余项:

$$\begin{aligned} |R_k| &\leq h^k \max_{|\alpha|=k} \sup_{\substack{\mathbf{x} \in \Omega \\ t \in [0,1]}} |D^\alpha f(\mathbf{a} + t(\mathbf{x} - \mathbf{a})) - D^\alpha f(\mathbf{a})| \frac{1}{k!} \sum_{\{\alpha \in \mathbb{N}_0^d \mid |\alpha|=k\}} \binom{k}{\alpha} \\ &\leq h^{k+s} \frac{d^{k+s/2}}{k!} \|f\|_{C^{k,s}(\Omega)}. \end{aligned}$$

这里使用了式 (7.4.1)、 $\|\mathbf{x} - \mathbf{a}\| \leq \sqrt{d}h$ , 以及由多项式公式得到的

$$\sum_{\{\alpha \in \mathbb{N}_0^d \mid |\alpha|=k\}} \binom{k}{\alpha} = (1 + \cdots + 1)^k = d^k.$$

□

现在给出本节的主要结论. 忽略对数因子, 它表明逼近  $C^{k,s}([0,1]^d)$  函数时可达到  $(k+s)/d$  的收敛率.

**定理 7.11:** 设  $d \in \mathbb{N}$ 、 $k \in \mathbb{N}_0$ 、 $s \in [0,1]$ . 则存在常数  $C > 0$ , 并且对每个  $N \in \mathbb{N}$ , 存在以  $\mathbf{w} \in \mathbb{R}^{\tilde{N}}$  为参数的 ReLU 神经网络  $\Phi_N(\mathbf{x}, \mathbf{w})$ , 使得

$$\text{size}(\Phi_N) = \tilde{N} \leq CN \log N, \quad \text{depth}(\Phi_N) \leq C \log N,$$

而且对每个  $f \in C^{k,s}(\Omega)$ ,

$$\inf_{\mathbf{w} \in \mathbb{R}^{\tilde{N}}} \|f(\mathbf{x}) - \Phi_N(\mathbf{x}, \mathbf{w})\|_{C^0([0,1]^d)} \leq C \|f\|_{C^{k,s}(\Omega)} N^{-(k+s)/d}. \quad (7.4.3)$$

**证明:** 证明采用所谓的单位分解方法 (partition of unity method). 首先构造单位分解  $(\varphi_\nu)_\nu$ , 使得对适当选取的  $M \in \mathbb{N}$ , 每个  $\varphi_\nu$  的支集都位于某点  $\boldsymbol{\eta} \in \Omega$  的  $O(1/M)$  邻域内. 在每个这样的邻域上, 用  $f$  在  $\boldsymbol{\eta}$  附近的局部 Taylor 多项式  $p_\nu$  逼近函数. 于是  $\sum_\nu \varphi_\nu p_\nu$  给出  $f$  在  $\Omega$  上的逼近. 该逼近可由形如  $\sum_\nu \Phi_\varepsilon^\times(\varphi_\nu, \hat{p}_\nu)$  的神经网络模拟, 其中  $\hat{p}_\nu$  是多项式  $p_\nu$  的神经网络逼近.

只需在

$$\max \left\{ \frac{d^{k+1/2}}{k!}, \exp(d) \right\} \|f\|_{C^{k,s}(\Omega)} \leq 1$$

的情形下证明定理; 一般情形立即由缩放论证得到.

步骤 1: 构造神经网络. 定义

$$M := \lceil N^{1/d} \rceil, \quad \varepsilon := N^{-(k+s)/d}. \quad (7.4.4)$$

考虑节点为  $\{\boldsymbol{\nu}/M \mid \boldsymbol{\nu} \leq M\}$  的均匀单纯形网格, 其中  $\boldsymbol{\nu}/M := (\nu_1/M, \dots, \nu_d/M)$ , 而“ $\boldsymbol{\nu} \leq M$ ”简记  $\{\boldsymbol{\nu} \in \mathbb{N}_0^d \mid \nu_i \leq M \text{ 对所有 } i \leq d\}$ . 记  $\varphi_\nu$  为该网格上的连续分段线性基函数, 它满足

$$\varphi_\nu(\boldsymbol{\nu}/M) = 1, \quad \varphi_\nu(\boldsymbol{\mu}/M) = 0 \quad \text{当 } \boldsymbol{\mu} \neq \boldsymbol{\nu}.$$

第 5 章已经证明,  $\varphi_\nu$  是规模为  $O(1)$  的神经网络. 此时

$$\sum_{\nu \leq M} \varphi_\nu \equiv 1 \quad \text{在 } \Omega \text{ 上} \quad (7.4.5)$$

是一个单位分解. 此外,

$$\text{supp}(\varphi_\nu) \subseteq \left\{ \mathbf{x} \in \Omega \mid \left\| \mathbf{x} - \frac{\nu}{M} \right\|_\infty \leq \frac{1}{M} \right\}, \quad (7.4.6)$$

其中  $\|\mathbf{x}\|_\infty = \max_{i \leq d} |x_i|$ .

对每个  $\nu \leq M$ , 定义多元多项式

$$p_\nu(\mathbf{x}) := \sum_{|\alpha| \leq k} \frac{D^\alpha f(\nu/M)}{\alpha!} (\mathbf{x} - \nu/M)^\alpha \in \mathbb{P}_k,$$

以及逼近

$$\hat{p}_\nu(\mathbf{x}) := \sum_{|\alpha| \leq k} \frac{D^\alpha f(\nu/M)}{\alpha!} \Phi_{|\alpha|, \varepsilon}^\times \left( x_{i_{\alpha,1}} - \frac{\nu_{i_{\alpha,1}}}{M}, \dots, x_{i_{\alpha,k}} - \frac{\nu_{i_{\alpha,k}}}{M} \right),$$

其中  $(i_{\alpha,1}, \dots, i_{\alpha,k}) \in \{0, \dots, d\}^k$  任意但固定, 并满足对每个  $r = 1, \dots, d$ ,

$$|\{j \mid i_{\alpha,j} = r\}| = \alpha_r.$$

最后定义

$$\Phi_N^f := \sum_{\nu \leq M} \Phi_\varepsilon^\times(\varphi_\nu, \hat{p}_\nu). \quad (7.4.7)$$

注意, 底层架构与  $f$  无关; 也就是说, 对某个网络架构  $\Phi_N$  及依赖于  $f$  的参数  $\mathbf{w}_f$ , 有  $\Phi_N^f(\mathbf{x}) = \Phi_N(\mathbf{x}, \mathbf{w}_f)$ .

步骤 2: 估计逼近误差. 首先, 对每个  $\mathbf{x} \in \Omega$ , 由式 (7.4.5) 与 (7.4.6),

$$\begin{aligned} \left| f(\mathbf{x}) - \sum_{\nu \leq M} \varphi_\nu(\mathbf{x}) p_\nu(\mathbf{x}) \right| &\leq \sum_{\nu \leq M} |\varphi_\nu(\mathbf{x})| |p_\nu(\mathbf{x}) - f(\mathbf{x})| \\ &\leq \max_{\nu \leq M} \sup_{\{\mathbf{y} \in \Omega \mid \|\nu/M - \mathbf{y}\|_\infty \leq 1/M\}} |f(\mathbf{y}) - p_\nu(\mathbf{y})|. \end{aligned}$$

由引理 7.10,

$$\sup_{\mathbf{x} \in \Omega} \left| f(\mathbf{x}) - \sum_{\nu \leq M} \varphi_\nu(\mathbf{x}) p_\nu(\mathbf{x}) \right| \leq M^{-(k+s)} \frac{d^{k+1/2}}{k!} \|f\|_{C^{k,s}(\Omega)} \leq M^{-(k+s)}. \quad (7.4.8)$$

接着固定  $\nu \leq M$  及满足  $\|\nu/M - \mathbf{y}\|_\infty \leq 1/M \leq 1$  的  $\mathbf{y} \in \Omega$ . 由命题 7.4,

$$\begin{aligned} |p_\nu(\mathbf{y}) - \hat{p}_\nu(\mathbf{y})| &\leq \sum_{|\alpha| \leq k} \frac{D^\alpha f(\nu/M)}{\alpha!} \left| \prod_{j=1}^k \left( y_{i_{\alpha,j}} - \frac{\nu_{i_{\alpha,j}}}{M} \right) \right. \\ &\quad \left. - \Phi_{|\alpha|, \varepsilon}^\times \left( y_{i_{\alpha,1}} - \frac{\nu_{i_{\alpha,1}}}{M}, \dots, y_{i_{\alpha,k}} - \frac{\nu_{i_{\alpha,k}}}{M} \right) \right| \\ &\leq \varepsilon \sum_{|\alpha| \leq k} \frac{D^\alpha f(\nu/M)}{\alpha!} \leq \varepsilon \exp(d) \|f\|_{C^{k,s}(\Omega)} \leq \varepsilon. \end{aligned} \quad (7.4.9)$$

这里使用了  $|D^\alpha f(\boldsymbol{\nu}/M)| \leq \|f\|_{C^{k,s}(\Omega)}$ , 以及

$$\begin{aligned} \sum_{\{\boldsymbol{\alpha} \in \mathbb{N}_0^d \mid |\boldsymbol{\alpha}| \leq k\}} \frac{1}{\boldsymbol{\alpha}!} &= \sum_{j=0}^k \frac{1}{j!} \sum_{\{\boldsymbol{\alpha} \in \mathbb{N}_0^d \mid |\boldsymbol{\alpha}|=j\}} \frac{j!}{\boldsymbol{\alpha}!} = \sum_{j=0}^k \frac{d^j}{j!} \\ &\leq \sum_{j=0}^{\infty} \frac{d^j}{j!} = \exp(d). \end{aligned}$$

类似地可证

$$|\hat{p}_\nu(\mathbf{x})| \leq \exp(d) \|f\|_{C^{k,s}(\Omega)} \leq 1, \quad \mathbf{x} \in \Omega.$$

固定  $\mathbf{x} \in \Omega$ . 该点属于网格中的某个单纯形, 因而至多落在  $d+1$  个函数  $\varphi_\nu$  的支集中, 这是一个单纯形的节点数. 此外, 引理 7.3 给出

$$\text{supp } \Phi_\varepsilon^\times(\varphi_\nu(\cdot), \hat{p}_\nu(\cdot)) \subseteq \text{supp } \varphi_\nu.$$

因而, 由引理 7.3 及式 (7.4.9),

$$\begin{aligned} &\left| \sum_{\nu \leq M} \varphi_\nu(\mathbf{x}) p_\nu(\mathbf{x}) - \sum_{\nu \leq M} \Phi_\varepsilon^\times(\varphi_\nu(\mathbf{x}), \hat{p}_\nu(\mathbf{x})) \right| \\ &\leq \sum_{\{\nu \leq M \mid \mathbf{x} \in \text{supp } \varphi_\nu\}} (|\varphi_\nu(\mathbf{x}) p_\nu(\mathbf{x}) - \varphi_\nu(\mathbf{x}) \hat{p}_\nu(\mathbf{x})| \\ &\quad + |\varphi_\nu(\mathbf{x}) \hat{p}_\nu(\mathbf{x}) - \Phi_\varepsilon^\times(\varphi_\nu(\mathbf{x}), \hat{p}_\nu(\mathbf{x}))|) \\ &\leq \varepsilon + (d+1)\varepsilon = (d+2)\varepsilon. \end{aligned}$$

结合式 (7.4.8), 总计得到

$$\sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - \Phi_N^f(\mathbf{x})| \leq M^{-(k+s)} + (d+2)\varepsilon.$$

代入式 (7.4.4) 中的选择, 便得到误差界 (7.4.3).

步骤 3: 估计式 (7.4.7) 中神经网络的规模与深度. 由引理 5.17, 对每个  $0 \leq \nu \leq M$ ,

$$\text{size}(\varphi_\nu) \leq C(1 + k_\mathcal{T}), \quad \text{depth}(\varphi_\nu) \leq C(1 + \log k_\mathcal{T}), \quad (7.4.10)$$

其中  $k_\mathcal{T}$  是网格中与一个节点相连的最大单纯形数.  $k_\mathcal{T}$  与  $M$  无关, 故  $\varphi_\nu$  的规模和深度均被与  $M$  无关的常数  $C_\varphi$  控制.

由引理 7.3、命题 7.4 及  $\varepsilon = N^{-(k+s)/d}$ ,

$$\begin{aligned} \text{depth}(\Phi_N^f) &= \text{depth}(\Phi_\varepsilon^\times) + \max_{\nu \leq M} \text{depth}(\varphi_\nu) + \max_{\nu \leq M} \text{depth}(\hat{p}_\nu) \\ &\leq C(1 + |\log \varepsilon| + C_\varphi) + \text{depth}(\Phi_{k,\varepsilon}^\times) \\ &\leq C(1 + |\log \varepsilon| + C_\varphi) \leq C(1 + \log N), \end{aligned}$$

其中  $C > 0$  依赖于  $k, d$ ; 这里用  $C$  表示可在各行改变取值的一般常数.

为估计规模, 先由引理 5.4 得到

$$\text{size}(\widehat{p}_\nu) \leq C \left( 1 + \sum_{|\alpha| \leq k} \text{size}(\Phi_{|\alpha|, \varepsilon}^\times) \right) \leq C(1 + |\log \varepsilon|),$$

其中  $C$  依赖于  $k$ . 因而, 取  $M = \lceil N^{1/d} \rceil$ , 有

$$\begin{aligned} \text{size}(\Phi_N^f) &\leq C \left( 1 + \sum_{\nu \leq M} (\text{size}(\Phi_\varepsilon^\times) + \text{size}(\varphi_\nu) + \text{size}(\widehat{p}_\nu)) \right) \\ &\leq C(1 + M)^d (1 + |\log \varepsilon| + C_\varphi) \\ &\leq C(1 + N^{1/d})^d (1 + C_\varphi + \log N) \leq CN \log N, \end{aligned}$$

证明完毕.  $\square$

定理 7.11 与文献 [332, Section 3.2] 精神相近; 主要差别在于, 该文研究  $C^k([0, 1]^d)$  而不是  $C^{k,s}([0, 1]^d)$ , 并使用近似单位分解, 而这里采用第 5 章构造的精确单位分解. 忽略对数因子, 该定理给出  $(k+s)/d$  的收敛率. 只要  $k$  足够大, 原则上便能得到任意大的收敛率; 当  $k \geq d$  时, 收敛率还可与  $d$  无关. 与定理 5.23 不同, 要取得误差  $N^{-(k+s)/d}$ , 这里需要  $O(\log N)$  的深度, 即神经网络深度必须增长. 不过也可以避免这一点: 深度为  $O(k/d)$  的网络已足以达到这些收敛率 [236].

**注 7.12:** 设  $L: \mathbf{x} \mapsto \mathbf{A}\mathbf{x} + \mathbf{b}: \mathbb{R}^d \rightarrow \mathbb{R}^d$  是双射仿射变换, 并令  $\Omega := L([0, 1]^d) \subseteq \mathbb{R}^d$ . 对函数  $f \in C^{k,s}(\Omega)$ , 由定理 7.11, 存在神经网络  $\Phi_N^f$ , 使得

$$\begin{aligned} \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - \Phi_N^f(L^{-1}(\mathbf{x}))| &= \sup_{\mathbf{x} \in [0, 1]^d} |f(L(\mathbf{x})) - \Phi_N^f(\mathbf{x})| \\ &\leq C \|_{C^{k,s}([0, 1]^d)} f \circ L N^{-(k+s)/d}. \end{aligned}$$

对  $\mathbf{x} \in [0, 1]^d$ , 有  $|f(L(\mathbf{x}))| \leq \sup_{\mathbf{y} \in \Omega} |f(\mathbf{y})|$ ; 若  $\mathbf{0} \neq \alpha \in \mathbb{N}_0^d$  是多重指标, 则

$$|D^\alpha(f(L(\mathbf{x})))| \leq \|A\|^{|\alpha|} \sup_{\mathbf{y} \in \Omega} |D^\alpha f(\mathbf{y})|.$$

因而

$$\|_{C^{k,s}([0, 1]^d)} f \circ L \leq (1 + \|A\|^{k+s}) \|f\|_{C^{k,s}(\Omega)}.$$

所以, 对任意仿射映射  $L$ , 在形如  $L([0, 1]^d)$  的每个集合上都能达到收敛率  $N^{-(k+s)/d}$ ; 特别地, 这对每个超矩形  $\times_{j=1}^d [a_j, b_j]$  都成立.  $\diamond$

## 文献与延伸阅读

本章基于 Yarotsky 于 2017 年发表的奠基性论文 [332]. 该文首次引入并分析了平方函数、乘法与多项式的逼近构造, 即第 7.1、7.2、7.3 节所讨论的内容. 该构造依赖于第 6.2 节讨论、最初由 Telgarsky 在文献 [305] 中构造的锯齿函数. 大约同时, Liang 与



Srikant 利用同时以 ReLU 和 Heaviside 函数作为激活函数的位提取技巧得到了类似结果 [184]. 这些工作使多项式逼近论能够提升到神经网络类, 并由此激发了大量研究; 基于这类论证的收敛结果包括文献 [236, 89, 204, 88, 228]. 关于有理逼近的相关结果, 另见文献 [307].

第 7.3 节的深度分离结果基于文献 [88, 228] 中解析函数的指数收敛率; 另见文献 [90, Lemma III.7]. 关于引理 7.5 所述 ReLU 神经网络对多项式的逼近, 可参见文献 [236, 90, 227], 以及使用可能更高效的 Chebyshev 多项式构造的文献 [225, 226]. 更多深度分离结果见文献 [305, 306, 91, 268, 9]. 与这类陈述密切相关的还有 Håstad 于 1987 年完成的论文 [142], 其中研究了逻辑电路在深度方面的限制.

第 7.4 节对  $C^{k,s}$  函数得到的逼近结果来自分段多项式函数的标准逼近论, 与文献 [332] 类似. 这类陈述也能对 ReLU 以外的激活函数证明: 对 S 形及光滑激活函数, 特别参见 Mhaskar 的文献 [198, 199] 以及 Pinkus 的 Acta Numerica 论文 [240] 第 6 节; 较新的文献 [76] 专门研究双曲正切激活函数. 最后, 文献 [118] 研究了允许构造近似单位分解的一般激活函数.

## 习题

## 习题

**7.13.** 证明另一类深度分离结果：设  $d \geq 2$ . 证明存在深度为二的 ReLU 神经网络  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}$ , 不能由深度为一的 ReLU 神经网络精确表示.

提示：证明非零的深度一 ReLU 神经网络必有无界支集.

**7.14.** 证明引理 7.5.

提示：对图 7.3 中的迭代深度作归纳.

**7.15.** 在  $f$  的 Taylor 级数只局部收敛的一般情形下证明命题 7.6 (见该命题的证明).

提示：使用定理 7.11 证明中的单位分解方法.

# 高维逼近

前几章建立了神经网络一致逼近函数  $f : [0, 1]^d \rightarrow \mathbb{R}$  的收敛率. 例如, 若  $f \in C^k([0, 1]^d)$ , 定理 7.11 给出关于网络规模  $N$  的误差界  $O(N^{-k/d})$  (忽略对数因子). 因此, 按照这一界, 要达到精度  $\varepsilon > 0$ , 需要网络规模  $N = O(\varepsilon^{-d/k})$ . 对固定的  $\varepsilon > 0$ , 网络规模必须随  $d$  呈指数增长. 这种对维数  $d$  的指数依赖称为维数灾难 (Curse of Dimensionality (CoD)) [26]. 本章将更详细地讨论维数灾难, 解释其成因, 并介绍若干能够缓解它的情形.

第 8.1 节回顾文献 [82, 223] 中的经典非线性逼近结果, 说明对  $C^k([0, 1]^d)$  这类光滑性空间, 在温和假设下, 任意神经网络架构都必然遭受维数灾难. 这表明此类函数空间在高维情形下往往过于一般. 因此, 后续各节引入更窄、也更适于高维高效逼近的函数类. 构造不遭受维数灾难的函数类并不困难, 难点在于找出有意义且与实践相关的函数类.

第 8.2 节考察一种限制函数 Fourier 域行为的假设, 它允许得到较慢但与维数无关的逼近率. 第 8.3 节研究具有特定复合结构的函数; 具体而言, 这类函数由简单低维子函数的复合与线性组合构成. 此时维数灾难仍然存在, 但只通过子函数的输入维数出现. 最后, 第 8.4 节研究函数仍定义在高维空间、但仅在高维输入空间的低维子流形上度量逼近精度的情形; 此时逼近率由流形的光滑性和维数控制.

## 8.1 维数灾难

考虑函数  $f : [0, 1]^d \rightarrow \mathbb{R}^m$ , 其中输入维数  $d$  与输出维数  $m$  都可能很大. 逼近  $f$  等价于分别逼近其  $m$  个分量函数  $f_i : [0, 1]^d \rightarrow \mathbb{R}$ ,  $i = 1, \dots, m$ . 因而, 算法的计算成本、模型复杂度和数据需求通常都关于  $m$  线性增长. 正因如此, 大输出维数  $m$  往往不被视为主要瓶颈; 输入维数  $d$  的作用则关键得多.

下文聚焦于  $C^k$  单位球中的函数  $f : [0, 1]^d \rightarrow \mathbb{R}$ , 即

$$B_1^{k,d} := \{f \in C^k([0, 1]^d) \mid \|f\|_{C^k([0, 1]^d)} \leq 1\}, \quad (8.1.1)$$

其中  $k \in \mathbb{N} \cup \{\infty\}$ , 比较定义 3.2. 更具体地, 我们研究关于范数

$$\|f\|_\infty := \sup_{x \in [0, 1]^d} |f(x)| \quad (8.1.2)$$

的一致逼近; 维数  $d$  总能由语境确定.<sup>1</sup> 目标是给出复杂度下界, 说明一个能够逼近  $B_1^{k,d}$  中所有函数的神经网络, 其复杂度必须如何随  $d$  增长.

<sup>1</sup>对连续函数  $f : [0, 1]^d \rightarrow \mathbb{R}$ , 范数  $\|f\|_\infty$  与  $\|f\|_{C^0([0, 1]^d)}$  相同. 这里明确采用  $\|\cdot\|_\infty$ , 因为并不要求  $f$  的逼近函数连续.

### 8.1.1 数据需求

考虑算法  $A$ : 它接收  $N$  个函数值  $f(\mathbf{x}_1), \dots, f(\mathbf{x}_N)$ , 并试图据此重建  $f \in B_1^{k,d} \subset C^k([0,1]^d)$ . 下文中, 算法在数学上仅指映射

$$A: \mathbb{R}^N \rightarrow \{g \mid g: [0,1]^d \rightarrow \mathbb{R}\},$$

即  $A$  接收  $\mathbb{R}^N$  中的一个向量并返回  $[0,1]^d$  上的一个函数. 在深度学习语境中, 例如,  $A$  可以把数据点  $f(\mathbf{x}_1), \dots, f(\mathbf{x}_N)$  映射到以这些数据点进行函数回归训练后神经网络所实现的函数. 本小节的目标是证明下述定理.

**定理 8.1:** 设  $k \in \mathbb{N}$ . 则存在  $C_k > 0$ , 使得对所有  $d, N \in \mathbb{N}$ 、所有  $\mathbf{x}_1, \dots, \mathbf{x}_N \in [0,1]^d$  以及所有映射  $A: \mathbb{R}^N \rightarrow \{g \mid g: [0,1]^d \rightarrow \mathbb{R}\}$ , 都有

$$\sup_{f \in B_1^{k,d}} \|f - A(f(\mathbf{x}_1), \dots, f(\mathbf{x}_N))\|_\infty \geq C_k N^{-k/d}.$$

该定理特别说明: 若对  $f$  的唯一先验知识是  $f \in B_1^{k,d}$ , 则要存在一种能以给定精度可靠重建  $f$  的算法, 所需采样点  $\mathbf{x}_1, \dots, \mathbf{x}_N$  的数量必然随  $d$  呈指数增长.

根本问题在于, 随着维数  $d$  增大, 区域  $[0,1]^d$  可以容纳指数多个互不相交的小区域, 使函数能够以越来越多的方式局部化. 因而, 函数类  $B_1^{k,d}$  的丰富程度实际上随  $d$  呈指数增长. 为精确说明这一点, 下面显式构造一系列这样的局部化函数; 它将直接导出定理 8.1 中的下界.

对  $\mathbf{x} \in \mathbb{R}^d$ , 引入鼓包函数 (bump function)

$$\psi(\mathbf{x}) := \begin{cases} \exp\left(1 - \frac{1}{1 - \|\mathbf{x}\|^2}\right), & \|\mathbf{x}\| \leq 1, \\ 0, & \text{其他情形.} \end{cases} \quad (8.1.3)$$

**引理 8.2:** 设  $d \in \mathbb{N}$ , 并对所有  $n \in \mathbb{N}$ 、 $\mathbf{x} \in \mathbb{R}^d$  令  $\psi_n := \psi(n\mathbf{x})$ . 则  $\psi_n \in C^\infty(\mathbb{R}^d)$ 、 $\|\psi_n\|_{C^0(\mathbb{R}^d)} = 1$ , 且

$$\text{supp}(\psi_n) \subseteq [-1/n, 1/n]^d.$$

此外, 对每个  $k \in \mathbb{N}$ , 存在与  $d$  无关的常数  $0 < C_{k,1} \leq C_{k,2}$ , 使得对所有  $n \in \mathbb{N}$ ,

$$n^k C_{k,1} \leq \|\psi_n\|_{C^k(\mathbb{R}^d)} \leq n^k C_{k,2}.$$

**证明:** 容易验证  $\psi \in C^\infty(\mathbb{R}^d)$ , 且其支集位于  $\{\mathbf{x} \in \mathbb{R}^d \mid \|\mathbf{x}\| \leq 1\} \subseteq [-1,1]^d$ . 因而  $\psi_n \in C^\infty(\mathbb{R}^d)$ , 且支集位于  $[-1/n, 1/n]^d$ . 此外, 由链式法则,

$$\begin{aligned} \|\psi_n\|_{C^k(\mathbb{R}^d)} &= \sup_{\mathbf{x} \in \mathbb{R}^d} \max_{\substack{\alpha \in \mathbb{N}_0^d \\ |\alpha| \leq k}} |D^\alpha \psi_n(\mathbf{x})| \\ &= \max_{\substack{\alpha \in \mathbb{N}_0^d \\ |\alpha| \leq k}} n^{|\alpha|} \underbrace{\sup_{\mathbf{x} \in \mathbb{R}^d} |D^\alpha \psi(\mathbf{x})|}_{=: C_{d,\alpha}}. \end{aligned}$$

因为  $\psi$  不是多项式, 所以每个  $\alpha \in \mathbb{N}_0^d$  都满足  $C_{d,\alpha} > 0$ .

固定  $r \geq k$ , 取满足  $|\alpha| = k$  且有  $j \leq k$  个非零分量的多重指标  $\alpha \in \mathbb{N}_0^r$ . 再令  $\beta \in \mathbb{N}_0^r$  是  $\alpha$  各分量的一个排列, 使其非零分量位于前  $j$  个位置. 由  $\psi$  的对称性,

$$\begin{aligned} C_{r,\alpha} &= \sup_{\mathbf{x} \in \mathbb{R}^r} |D^\alpha \psi(\mathbf{x})| = \sup_{\mathbf{x} \in \mathbb{R}^r} |D^\beta \psi(\mathbf{x})| \\ &= \sup_{\mathbf{x} \in \mathbb{R}^r} \left| D^\beta \exp \left( 1 - \frac{1}{1 - \|\mathbf{x}\|^2} \right) \right|. \end{aligned}$$

从最后一个表达式可见, 当  $x_{j+1} = \cdots = x_r = 0$  时达到上确界. 因而, 令  $\tilde{\beta} = (\beta_1, \dots, \beta_k) \in \mathbb{N}_0^k$ , 便有

$$\begin{aligned} C_{r,\alpha} &= \sup_{\mathbf{x} \in \mathbb{R}^r} \left| D^\beta \exp \left( 1 - \frac{1}{1 - \|\mathbf{x}\|^2} \right) \right| \\ &= \sup_{\mathbf{x} \in \mathbb{R}^k} \left| D^{\tilde{\beta}} \exp \left( 1 - \frac{1}{1 - \|\mathbf{x}\|^2} \right) \right| = C_{k,\tilde{\beta}}. \end{aligned}$$

所以

$$\sup_{r \geq k} \max_{\substack{\alpha \in \mathbb{N}_0^r \\ |\alpha|=k}} C_{r,\alpha} = \max_{\substack{\tilde{\beta} \in \mathbb{N}_0^k \\ |\tilde{\beta}|=k}} C_{k,\tilde{\beta}}.$$

最后, 对所有  $d, n \in \mathbb{N}$ ,

$$\begin{aligned} 0 < C_{k,1} &:= \min_{r=1,\dots,k} \max_{\substack{\alpha \in \mathbb{N}_0^r \\ |\alpha|=k}} C_{r,\alpha} \leq n^{-k} \|\psi_n\|_{C^k(\mathbb{R}^d)} \\ &\leq \max_{r=1,\dots,k} \max_{|\alpha| \leq k} C_{r,\alpha} =: C_{k,2} < \infty, \end{aligned}$$

从而得到结论. □

下一个引理是上述结果的直接推论, 并给出前面所说的函数序列.

**引理 8.3:** 对  $\nu \in \{1, \dots, n\}^d$ , 令

$$\psi_{\nu,n}(\mathbf{x}) := \frac{1}{C_{2,k}(3n)^k} \psi_{3n} \left( \mathbf{x} - \frac{\nu}{n+1} \right).$$

则当  $\mu \neq \nu$  时,  $\text{supp}(\psi_{\nu,n}) \cap \text{supp}(\psi_{\mu,n}) = \emptyset$ ; 并且对所有  $\nu \in \{1, \dots, n\}^d$ ,

$$\|\psi_{\nu,n}\|_{C^0([0,1]^d)} = \frac{1}{C_{2,k}(3n)^k}, \quad \|\psi_{\nu,n}\|_{C^k([0,1]^d)} \leq 1.$$

**定理 8.1 的证明:** 固定  $d, k \in \mathbb{N}$ , 并取  $n \in \mathbb{N}$  使  $n^d \leq N < (n+1)^d$ . 函数  $\psi_{\nu,n+1}$  ( $\nu \in \{1, \dots, n+1\}^d$ ) 共有  $(n+1)^d$  个, 且支集两两不交. 因而至少存在一个  $\nu$ , 使得

$$\mathbf{x}_j \notin \text{supp} \psi_{\nu,n+1}, \quad j = 1, \dots, N.$$

令  $f := \psi_{\nu, n+1} \in B_1^{k,d}$ . 注意  $-f \in B_1^{k,d}$ , 且

$$g := A(f(\mathbf{x}_1), \dots, f(\mathbf{x}_N)) = A(-f(\mathbf{x}_1), \dots, -f(\mathbf{x}_N)).$$

有

$$2C_{2,k}(3(n+1))^{-k} = 2\|f\|_\infty \leq \|f - g\|_\infty + \|f + g\|_\infty.$$

因而下列两个不等式至少有一个成立：

$$\|f - g\|_\infty \geq (C_{2,k}(3(n+1))^k)^{-1}, \quad \text{或} \quad \|f + g\|_\infty \geq (C_{2,k}(3(n+1))^k)^{-1}.$$

利用  $n - 1 \leq N^{1/d}$ , 得到

$$(C_{2,k}(3(n+1))^k)^{-1} \geq C_{2,k}^{-1} 2^{-k} (3n)^{-k} \geq C_{2,k}^{-1} 6^{-k} N^{-k/d},$$

从而证明结论. □

### 8.1.2 参数数量

沿用文献 [252], 考虑形如

$$R \circ W(f), \quad f \in B_1^{k,d},$$

的逼近, 其中  $W : C^0([0, 1]^d) \rightarrow \mathbb{R}^N$  连续,<sup>2</sup> 而  $R : \mathbb{R}^N \rightarrow \{g \mid g : [0, 1]^d \rightarrow \mathbb{R}\}$  是任意映射. 对这些函数作如下解释:

- 权重映射  $W$  为给定目标函数  $f$  指定  $N$  个参数, 例如网络权重;
- 实现映射  $R$  接收  $N$  维参数  $W \in \mathbb{R}^N$ , 返回函数  $g : [0, 1]^d \rightarrow \mathbb{R}$ , 例如具有权重  $W$  的神经网络所实现的函数. 若  $R$  是到某个函数空间的光滑映射, 则其像可以解释为该函数空间中的  $N$  维子流形.

定义  $B_1^{k,d}$  的连续非线性  $N$ -宽度 (continuous nonlinear  $N$ -width)

$$\gamma_{k,d,N} := \inf_{\substack{W: C^0([0,1]^d) \rightarrow \mathbb{R}^N \text{ 连续} \\ R: \mathbb{R}^N \rightarrow \{g \mid g: [0,1]^d \rightarrow \mathbb{R}\}}} \sup_{f \in B_1^{k,d}} \|f - R(W(f))\|_\infty. \quad (8.1.4)$$

本小节证明下述关于  $\gamma_{k,d,N}$  的下界 [252, Theorem 4.2].

**定理 8.4:** 设  $k \in \mathbb{N}$ . 则存在  $C_k > 0$ , 使得对所有  $d, N \in \mathbb{N}$ ,

$$\gamma_{k,d,N} \geq C_k N^{-k/d}.$$

**注 8.5:** 定理 8.1 是定理 8.4 的特例, 只需取  $A = R$  及  $W(f) = (f(\mathbf{x}_1), \dots, f(\mathbf{x}_N))$ .  $\diamond$

---

<sup>2</sup>在第 8.1.2、8.1.3 节中, 只需假设  $W : B_1^{k,d} \rightarrow \mathbb{R}^N$  关于  $B_1^{k,d}$  上的  $C^0([0, 1]^d)$  拓扑连续.

定理 8.4 回答了以下问题：用由  $N \in \mathbb{N}$  个实数连续参数化的函数类一致逼近  $B_1^{k,d}$  中的所有函数时，最坏情形误差能有多小？直接推论如下，它对任意神经网络架构给出所需网络规模的下界，而不论激活函数、宽度、深度或稀疏模式如何。

**推论 8.6：** 对每个  $N \in \mathbb{N}$ ，设  $\Phi_N(\cdot, \mathbf{w})$  是输入维数为  $d$ 、参数  $\mathbf{w} \in \mathbb{R}^N$  的前馈神经网络，即

$$\text{size}(\Phi_N) = N$$

(比较定义 2.1、2.4)。则存在  $C_k$ ，使得对所有  $d, N \in \mathbb{N}$  及任意连续权重选择  $W : C^0([0, 1]^d) \rightarrow \mathbb{R}^N$ ，

$$\sup_{f \in B_1^{k,d}} \|f - \Phi(\cdot, W(f))\|_\infty \geq C_k N^{-k/d}.$$

推论 8.6 的证明只需把定理 8.4 应用于映射  $R : \mathbf{w} \mapsto \Phi_N(\cdot, \mathbf{w})$ 。该陈述再次展现维数灾难：对任意连续权重选择过程和规模至多为  $N \in \mathbb{N}$  的任意神经网络架构，最佳可达一致逼近误差都以下界  $C_k N^{-k/d}$  为界。特别地，要达到固定精度  $\varepsilon$ ，必须有

$$N \geq \left( \frac{C_k}{\varepsilon} \right)^{d/k}, \quad (8.1.5)$$

即参数数量随  $d$  指数增长。

**注 8.7：** 定理 7.11 已经说明，前馈 ReLU 神经网络确实能够达到收敛率  $N^{-k/d}$ （忽略对数因子）。此外，该定理证明中构造的具体权重对应于连续权重选择。因而，在这一特定意义下，ReLU 神经网络本质上是最优的。  $\diamond$

$W$  的连续性是使上述陈述有意义的关键限制。对神经网络而言，它意味着：当  $f$  与  $\tilde{f}$  在  $C^0([0, 1]^d)$  中很接近时，相应网络权重也必须接近。这是一个合理假设：若  $W$  不连续，权重选择过程就高度不稳定，因而很可能无法在实践中计算。如果允许任意映射  $W : B_1^{k,d} \rightarrow \mathbb{R}^N$ ，那么即使额外假设  $R$  连续，式 (8.1.4) 中的下确界也会变成零。这是由于存在空间填充曲线及类似病态现象，见图 8.1。实际上，第 3 章的命题 3.20 已经给过一个例子：对某个特殊激活函数， $C^0([0, 1])$  中的所有函数都能由仅使用一个参数的神经网络任意精确地逼近。建议读者重温其证明，并验证此时的权重选择映射显然不连续。

下面证明定理 8.4。论证的一个关键组成部分是 Borsuk–Ulam 定理 [39, 293]，先回顾如下。

**定理 8.8 (Borsuk–Ulam)：** 设  $N \in \mathbb{N}$ 、 $N \geq 2$ ，并以  $S^{N-1} \subseteq \mathbb{R}^N$  表示  $(N-1)$ -维球面。设  $f : S^{N-1} \rightarrow \mathbb{R}^N$  连续且为奇映射，即对所有  $\mathbf{x} \in S^{N-1}$  都有  $f(-\mathbf{x}) = -f(\mathbf{x})$ 。则至少存在一个  $\mathbf{x} \in S^{N-1}$ ，使得  $f(\mathbf{x}) = \mathbf{0} \in \mathbb{R}^N$ 。

下一个引理对应文献 [252, Theorem 3.1]。尽管式 (8.1.4) 中的  $\gamma_{k,d,N}$  看似相当复杂，该引理却给出一个出人意料的简单论证来导出其下界。

**引理 8.9：** 设  $k \in \mathbb{N} \cup \{\infty\}$ ， $X_N$  是  $C^k([0, 1]^d)$  的  $N$  维子空间，其中  $N \geq 2$ ；并假设对某个  $\rho > 0$ ，

$$\{f \in X_N \mid \|f\|_\infty = \rho\} \subseteq B_1^{k,d}.$$






图 8.1: (近似) 空间填充曲线  $R: w \mapsto R(w)$  可以通过依赖低维参数  $w$  的映射  $R$ , 任意精确地逼近高维空间中的元素. 然而,  $R(w_1)$  与  $R(w_2)$  接近一般并不蕴含参数  $w_1$  与  $w_2$  接近.

则  $\gamma_{k,d,N} \geq \rho$ .

**证明:** 固定连续映射  $W: C^0([0,1]^d) \rightarrow \mathbb{R}^N$  和任意映射  $R: \mathbb{R}^N \rightarrow \{g \mid g: [0,1]^d \rightarrow \mathbb{R}\}$ . 令

$$\widetilde{W}(f) := W(f) - W(-f),$$

则  $\widetilde{W}: C^0([0,1]^d) \rightarrow \mathbb{R}^N$  连续且为奇映射. 固定  $X_N$  的一组基  $\psi_1, \dots, \psi_N$ , 并对  $(x_1, \dots, x_N) \in S^{N-1} \subseteq \mathbb{R}^N$  定义

$$\phi(x_1, \dots, x_N) := \rho \frac{\sum_{j=1}^N x_j \psi_j}{\|_{C^0([0,1]^d)} \sum_{j=1}^N x_j \psi_j}.$$

容易验证, 映射

$$\phi: S^{N-1} \rightarrow \{f \in X_N \mid \|f\|_{C^0([0,1]^d)} = \rho\} \subseteq C^0([0,1]^d)$$

连续且为奇映射. 因而

$$\widetilde{W} \circ \phi: S^{N-1} \rightarrow \mathbb{R}^N$$

连续且为奇映射. 由 Borsuk–Ulam 定理, 该映射至少有一个零点. 所以存在

$$f_0 \in \{f \in X_N \mid \|f\|_\infty = \rho\} \subseteq B_1^{k,d}$$

满足  $\widetilde{W}(f_0) = \mathbf{0} \in \mathbb{R}^N$ , 即  $W(f_0) = W(-f_0)$ .

于是

$$2\rho = 2\|f_0\|_\infty \leq \|f_0 - R(W(f_0))\|_\infty + \|-f_0 - R(W(-f_0))\|_\infty.$$

因而, 由  $f_0, -f_0 \in B_1^{k,d}$ , 下列两个不等式至少有一个成立:

$$\|f_0 - R(W(f_0))\|_\infty \geq \rho, \quad \text{或} \quad \|-f_0 - R(W(-f_0))\|_\infty \geq \rho.$$

因  $W, R$  任意, 结论成立.  $\square$

**定理 8.4 的证明:** 固定  $n \in \mathbb{N}$  使得  $n^d \leq N \leq (n+1)^d := \tilde{N}$ , 并以引理 8.3 中的函数定义

$$X_{\tilde{N}} := \text{span}\{\psi_{\nu, n+1} \mid \nu \in \{1, \dots, n+1\}^d\}.$$

因为  $\psi_{\nu, n+1}$  的支集两两不交, 由引理 8.3, 取  $\rho := (C_{2,k}3(n+1)^k)^{-1}$ , 有

$$\{f \in X_{\tilde{N}} \mid \|f\|_\infty = \rho\} \subseteq B_1^{k,d}.$$

因而引理 8.9 给出

$$\gamma_{k,d,N} \geq \gamma_{k,d,\tilde{N}} \geq \rho = (C_{2,k}3(n+1)^k)^{-1} \geq C_{2,k}^{-1}6^{-k}N^{-k/d},$$

其中最后一个不等式与定理 8.4 证明中的论证相同.  $\square$

### 8.1.3 无穷次可微函数

至此已经看到, 对固定且有限的  $k \in \mathbb{N}$ , 逼近  $C^k([0, 1]^d)$  中的函数会遭受维数灾难. 定理 7.11 的分析以及式 (8.1.5) 表明, 至少就渐近收敛率而言, 大维数  $d$  可以用大的  $k$  补偿. 这自然引出问题: 若允许  $k$  随  $d$  增长, 能否打破维数灾难? 答案是否定的. 即使对  $C^\infty$  函数, 维数灾难一般仍然存在. 下一个定理对应文献 [223, Theorem 1], 它表明, 要对  $B_1^{\infty,d}$  ( $C^\infty([0, 1]^d)$  中的单位球) 的所有函数达到固定逼近精度, 参数数量  $N$  仍必须随  $d$  指数增长.

**定理 8.10:** 对所有  $d \in \mathbb{N}$ 、 $d \geq 2$ ,

$$\gamma_{\infty,d,2^{\lfloor d/2 \rfloor}} \geq 1.$$

对神经网络可得如下推论.

**推论 8.11:** 对每个  $d \in \mathbb{N}$ 、 $d \geq 2$ , 设  $\Phi_d(\cdot, \mathbf{w})$  是输入维数为  $d$ 、参数  $\mathbf{w} \in \mathbb{R}^{2^{\lfloor d/2 \rfloor}}$  的神经网络, 即

$$\text{size}(\Phi_d) = 2^{\lfloor d/2 \rfloor}.$$

则对每个  $d \geq 2$  及每个连续权重选择  $W_d : C^0([0, 1]^d) \rightarrow \mathbb{R}^{2^{\lfloor d/2 \rfloor}}$ ,

$$\sup_{f \in B_1^{\infty,d}} \|f - \Phi_d(\cdot, W_d(f))\|_\infty \geq 1.$$

**定理 8.10 的证明:** 固定  $d \geq 2$ , 令  $s := \lfloor d/2 \rfloor \geq 1$ . 将构造维数为  $2^s$  的空间  $X_d \subseteq C^\infty([0, 1]^d)$ , 使得

$$\{f \in X_d \mid \|f\|_\infty = 1\} \subseteq \{f \in C^\infty([0, 1]^d) \mid \|f\|_{C^\infty([0, 1]^d)} \leq 1\} = B_1^{\infty, d}. \quad (8.1.6)$$

再结合引理 8.9 即可完成证明.

步骤 1. 断言: 对  $a, b \in \mathbb{R}$  及  $g(z) := a + bz$ , 任意  $k \in \mathbb{N}_0$  都满足

$$\sup_{z \in [0, 2]} |g(z)| \geq \sup_{z \in [0, 2]} |g^{(k)}(z)|.$$

因  $k \geq 2$  时  $g^{(k)} \equiv 0$ , 只需考虑  $k = 1$ , 此时

$$\max\{|a|, |a + 2b|\} = \sup_{z \in [0, 2]} |g(z)| \geq \sup_{x \in [0, 2]} |g'(z)| = |b|.$$

若该不等式不成立, 则  $|a| + |a + 2b| < |2b|$ , 从而得到矛盾  $|2b| \leq |-a| + |a + 2b| < |2b|$ .

步骤 2. 对  $\mathbf{a} = (a_\nu)_{\nu \in \{0, 1\}^s} \in \mathbb{R}^{2^s}$ , 定义

$$f_{\mathbf{a}}(\mathbf{x}) := \sum_{\nu \in \{0, 1\}^s} a_\nu (x_1 + x_2)^{\nu_1} (x_3 + x_4)^{\nu_2} \cdots (x_{2s-1} + x_{2s})^{\nu_s}, \quad \mathbf{x} \in [0, 1]^d.$$

将证明  $2^s$  维函数空间

$$X_d := \{f_{\mathbf{a}}(\mathbf{x}) \mid \mathbf{a} \in \mathbb{R}^{2^s}\} \subseteq C^\infty([0, 1]^d)$$

满足式 (8.1.6).

固定  $\mathbf{a} \in \mathbb{R}^{2^s}$ , 并定义

$$g_{\mathbf{a}}(\mathbf{z}) := \sum_{\nu \in \{0, 1\}^s} a_\nu z_1^{\nu_1} z_2^{\nu_2} \cdots z_s^{\nu_s}, \quad \mathbf{z} \in [0, 2]^s.$$

固定多重指标  $\beta \in \mathbb{N}_0^s$ . 对每个  $j$ , 函数  $z_j \mapsto g_{\mathbf{a}}(z_1, \dots, z_s)$  及  $g_{\mathbf{a}}$  的任意偏导数都关于  $z_j$  仿射线性. 由步骤 1,

$$\begin{aligned} \sup_{\mathbf{z} \in [0, 2]^s} |D^\beta g_{\mathbf{a}}(\mathbf{z})| &= \sup_{z_2, \dots, z_s \in [0, 2]} \sup_{z_1 \in [0, 2]} \left| \frac{\partial^{\beta_1}}{\partial z_1^{\beta_1}} \cdots \frac{\partial^{\beta_s}}{\partial z_s^{\beta_s}} g_{\mathbf{a}}(z_1, \dots, z_s) \right| \\ &\leq \sup_{z_2, \dots, z_s \in [0, 2]} \sup_{z_1 \in [0, 2]} \left| \frac{\partial^{\beta_2}}{\partial z_2^{\beta_2}} \cdots \frac{\partial^{\beta_s}}{\partial z_s^{\beta_s}} g_{\mathbf{a}}(z_1, \dots, z_s) \right| \\ &\leq \cdots \leq \sup_{\mathbf{z} \in [0, 2]^s} |g_{\mathbf{a}}(\mathbf{z})|. \end{aligned}$$

现任取  $\alpha \in \mathbb{N}_0^d$ . 对  $j = 1, \dots, s$ , 令  $\beta_j = \alpha_{2j-1} + \alpha_{2j}$ ,  $z_j = x_{2j-1} + x_{2j}$ , 则

$$D^\beta g_{\mathbf{a}}(z_1, \dots, z_s) = D^\alpha f_{\mathbf{a}}(x_1, \dots, x_d).$$

因而

$$\begin{aligned} \sup_{\mathbf{x} \in [0, 1]^d} \sup_{\alpha \in \mathbb{N}_0^d} |D^\alpha f_{\mathbf{a}}(\mathbf{x})| &= \sup_{\mathbf{z} \in [0, 2]^s} \sup_{\beta \in \mathbb{N}_0^s} |D^\beta g_{\mathbf{a}}(\mathbf{z})| \\ &= \sup_{\mathbf{z} \in [0, 2]^s} |g_{\mathbf{a}}(\mathbf{z})| = \sup_{\mathbf{x} \in [0, 1]^d} |f_{\mathbf{a}}(\mathbf{x})|. \end{aligned}$$

这说明对任意  $f \in X_d$ , 都有  $\|f\|_\infty = \|\cdot\|_{C^\infty([0, 1]^d)} f$ , 故式 (8.1.6) 成立.  $\square$

## 8.2 Barron 类

Barron 在文献 [17] 中引入了一类能够由神经网络逼近而不受维数灾难影响的函数. 这一函数集称为 Barron 类 (Barron class), 其特征由一种特殊的有界变差刻画. 为给出定义, 对  $g \in L^1(\mathbb{R}^d)$ , 记

$$\check{g}(\mathbf{w}) := \int_{\mathbb{R}^d} g(\mathbf{x}) e^{i\mathbf{w}^\top \mathbf{x}} d\mathbf{x}$$

为其逆 Fourier 变换. 对  $C > 0$ , 定义 Barron 类

$$\Gamma_C := \left\{ f \in C(\mathbb{R}^d) \mid \exists g \in L^1(\mathbb{R}^d), \int_{\mathbb{R}^d} |\boldsymbol{\xi}| |g(\boldsymbol{\xi})| d\boldsymbol{\xi} \leq C \text{ 且 } f = \check{g} \right\}.$$

我们称  $f \in \Gamma_C$  具有有限 Fourier 矩; 严格来说,  $f$  的 Fourier 变换未必有定义, 因为  $f$  不必可积. 由 Riemann–Lebesgue 引理 [115, Lemma 1.1.1], 只要定义中所述的  $g \in L^1(\mathbb{R}^d)$  存在, 条件  $f \in C(\mathbb{R}^d)$  就自动满足.

下面关于  $\Gamma_C$  中函数的逼近结果由文献 [17] 给出, 证明的表述与文献 [238, Section 5] 相近.

**定理 8.12:** 设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 S 形的 (见定义 3.12), 且对某个  $C > 0$  有  $f \in \Gamma_C$ . 记单位球为  $B_1^d := \{\mathbf{x} \in \mathbb{R}^d \mid \|\mathbf{x}\| \leq 1\}$ . 则对每个  $c > 4C^2$  和每个  $N \in \mathbb{N}$ , 都存在架构为  $(\sigma; d, N, 1)$  的神经网络  $\Phi^f$ , 使得

$$\frac{1}{|B_1^d|} \int_{B_1^d} |f(\mathbf{x}) - \Phi^f(\mathbf{x})|^2 d\mathbf{x} \leq \frac{c}{N}, \quad (8.2.1)$$

其中  $|B_1^d|$  是  $B_1^d$  的 Lebesgue 测度.

**注 8.13:** 在对激活函数施加某些假设时, 例如取 ReLU 的幂, 式 (8.2.1) 中的逼近率还可略微改进 [288].  $\diamond$

关键在于, 式 (8.2.1) 右端不含维数  $d$ ; 特别地, 收敛率不直接受维数影响, 这与前几章的结果形成鲜明对照. 不过应注意, 常数  $C$  仍可能内在地依赖于  $d$ , 见习题 8.21.

定理 8.12 的证明基于高维凸集的一种特殊性质, 它由 (近似) Carathéodory 定理描述; 其原始版本见文献 [54]. 下面引理所述的更一般版本依照文献 [318, Theorem 0.0.2] 以及 [17, 242]. 为陈述该结果, 回顾  $\overline{\text{co}}(G)$  表示  $G$  的凸包的闭包.

**引理 8.14:** 设  $H$  是 Hilbert 空间,  $G \subseteq H$ , 并且对某个  $B > 0$ , 所有  $g \in G$  都满足  $\|g\|_H \leq B$ . 设  $f \in \overline{\text{co}}(G)$ . 则对每个  $N \in \mathbb{N}$  和每个  $c > B^2$ , 存在  $(g_i)_{i=1}^N \subseteq G$ , 使得

$$\left\| f - \frac{1}{N} \sum_{i=1}^N g_i \right\|_H^2 \leq \frac{c}{N}. \quad (8.2.2)$$

**证明:** 固定  $\varepsilon > 0$  和  $N \in \mathbb{N}$ . 由于  $f \in \overline{\text{co}}(G)$ , 存在总和为 1 的系数  $\alpha_1, \dots, \alpha_m \in [0, 1]$ , 以及线性无关的元素  $h_1, \dots, h_m \in G$ , 使

$$f^* := \sum_{j=1}^m \alpha_j h_j$$

满足  $\|f - f^*\|_H < \varepsilon$ . 我们断言, 存在  $g_1, \dots, g_N$ , 每个都属于  $\{h_1, \dots, h_m\}$ , 使得

$$\left\| f^* - \frac{1}{N} \sum_{j=1}^N g_j \right\|_H^2 \leq \frac{B^2}{N}. \quad (8.2.3)$$

由于  $\varepsilon > 0$  任意, 这便能完成证明. 又因为从  $\text{span}\{h_1, \dots, h_m\}$  到  $\mathbb{R}^m$  存在等距同构, 所以下面不失一般性地假设  $H = \mathbb{R}^m$ .

令  $X_i$  ( $i = 1, \dots, N$ ) 为独立同分布的  $\mathbb{R}^m$  值随机变量, 满足

$$\mathbb{P}[X_i = h_j] = \alpha_j \quad \text{对所有 } i = 1, \dots, m.$$

特别地, 对每个  $i$  都有  $\mathbb{E}[X_i] = \sum_{j=1}^m \alpha_j h_j = f^*$ . 此外,

$$\begin{aligned} \mathbb{E} \left[ \left\| f^* - \frac{1}{N} \sum_{j=1}^N X_j \right\|_H^2 \right] &= \mathbb{E} \left[ \left\| \frac{1}{N} \sum_{j=1}^N (f^* - X_j) \right\|_H^2 \right] \\ &= \frac{1}{N^2} \left[ \sum_{j=1}^N \|f^* - X_j\|_H^2 + \sum_{i \neq j} \langle f^* - X_i, f^* - X_j \rangle_H \right] \\ &= \frac{1}{N} \mathbb{E}[\|f^* - X_1\|_H^2] \\ &= \frac{1}{N} \mathbb{E}[\|f^*\|_H^2 - 2 \langle f^*, X_1 \rangle_H + \|X_1\|_H^2] \\ &= \frac{1}{N} \mathbb{E}[\|X_1\|_H^2 - \|f^*\|_H^2] \leq \frac{B^2}{N}. \end{aligned} \quad (8.2.4)$$

这里使用了  $(X_i)_{i=1}^N$  独立同分布、 $\mathbb{E}[X_i] = f^*$ , 以及当  $i \neq j$  时  $\mathbb{E}\langle f^* - X_i, f^* - X_j \rangle = 0$ . 由于式 (8.2.4) 中的期望不超过  $B^2/N$ , 随机变量  $X_i \in \{h_1, \dots, h_m\}$  至少有一个实现满足式 (8.2.3); 将该实现记为  $g_i$ .  $\square$

引理 8.14 提供了一个强有力的工具: 若要用集合  $G$  中  $N$  个元素的叠加来逼近函数  $f$ , 只需证明  $f$  可以表示为  $G$  中元素的任意 (无限) 凸组合.

引理 8.14 表明, 为证明定理 8.12, 可以证明每个  $\Gamma_C$  中的函数都属于所有单神经元网络之凸包的闭包, 也就是 S 形激活函数  $\sigma$  的所有仿射变换的凸包闭包. 在证明这一点之前, 先稍作迂回. 我们首先证明, 每个  $f \in \Gamma_C$  都属于 Heaviside 函数所有仿射变换之凸包的闭包, 即集合

$$G_C := \{B_1^d \ni \mathbf{x} \mapsto \gamma \cdot \mathbb{1}_{\mathbb{R}_+}(\langle \mathbf{a}, \mathbf{x} \rangle + b) \mid \mathbf{a} \in \mathbb{R}^d, b \in \mathbb{R}, |\gamma| \leq 2C\}.$$

下面的引理对应于文献 [17, Theorem 2] 和文献 [238, Lemma 5.12], 它建立了  $\Gamma_C$  与  $G_C$  之间的联系.

**引理 8.15:** 设  $d \in \mathbb{N}$ 、 $C > 0$  且  $f \in \Gamma_C$ . 则  $f|_{B_1^d} - f(\mathbf{0}) \in \overline{\text{co}}(G_C)$ , 其中闭包关于范数

$$\|g\|_{L^{2,\diamond}(B_1^d)} := \left( \frac{1}{|B_1^d|} \int_{B_1^d} |g(\mathbf{x})|^2 d\mathbf{x} \right)^{1/2} \quad (8.2.5)$$

而取.

**证明： 步骤 1.** 将  $f(\mathbf{x})$  表示为积分.

由于  $f \in \Gamma_C$ , 存在  $g \in L^1(\mathbb{R}^d)$ , 使得对所有  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\begin{aligned} f(\mathbf{x}) - f(\mathbf{0}) &= \int_{\mathbb{R}^d} g(\boldsymbol{\xi}) (e^{i\langle \mathbf{x}, \boldsymbol{\xi} \rangle} - 1) d\boldsymbol{\xi} \\ &= \int_{\mathbb{R}^d} |g(\boldsymbol{\xi})| (e^{i(\langle \mathbf{x}, \boldsymbol{\xi} \rangle + \kappa(\boldsymbol{\xi}))} - e^{i\kappa(\boldsymbol{\xi})}) d\boldsymbol{\xi} \\ &= \int_{\mathbb{R}^d} |g(\boldsymbol{\xi})| (\cos(\langle \mathbf{x}, \boldsymbol{\xi} \rangle + \kappa(\boldsymbol{\xi})) - \cos(\kappa(\boldsymbol{\xi}))) d\boldsymbol{\xi}, \end{aligned} \quad (8.2.6)$$

其中  $\kappa(\boldsymbol{\xi})$  是  $g(\boldsymbol{\xi})$  的相位, 即  $g(\boldsymbol{\xi}) = |g(\boldsymbol{\xi})|e^{i\kappa(\boldsymbol{\xi})}$ ; 最后一个等式来自  $f$  为实值函数. 通过 Lebesgue 密度在  $\mathbb{R}^d$  上定义测度  $\mu$ :

$$d\mu(\boldsymbol{\xi}) := \frac{1}{C'} |\boldsymbol{\xi}| |g(\boldsymbol{\xi})| d\boldsymbol{\xi},$$

其中  $C' := \int |\boldsymbol{\xi}| |g(\boldsymbol{\xi})| d\boldsymbol{\xi} \leq C$ ; 由于  $f \in \Gamma_C$ , 这是可行的. 于是式 (8.2.6) 给出

$$f(\mathbf{x}) - f(\mathbf{0}) = C' \int_{\mathbb{R}^d} \frac{\cos(\langle \mathbf{x}, \boldsymbol{\xi} \rangle + \kappa(\boldsymbol{\xi})) - \cos(\kappa(\boldsymbol{\xi}))}{|\boldsymbol{\xi}|} d\mu(\boldsymbol{\xi}). \quad (8.2.7)$$

**步骤 2.** 证明映射  $\mathbf{x} \mapsto f(\mathbf{x}) - f(\mathbf{0})$  属于函数  $\mathbf{x} \mapsto q_{\mathbf{x}}(\boldsymbol{\theta})$  ( $\boldsymbol{\theta} \in \mathbb{R}^d$ ) 的凸组合在  $L^{2,\diamond}(B_1^d)$  中的闭包, 其中

$$\begin{aligned} q_{\mathbf{x}} : B_1^d &\rightarrow \mathbb{R}, \\ \boldsymbol{\xi} &\mapsto C' \frac{\cos(\langle \mathbf{x}, \boldsymbol{\xi} \rangle + \kappa(\boldsymbol{\xi})) - \cos(\kappa(\boldsymbol{\xi}))}{|\boldsymbol{\xi}|}. \end{aligned} \quad (8.2.8)$$

余弦函数是 1-Lipschitz 的. 因而对任意  $\boldsymbol{\xi} \in \mathbb{R}^d$ , 映射 (8.2.8) 均由 1 控制. 此外容易看出,  $q_{\mathbf{x}}$  即使在原点也有良定义且连续. 因此, 对  $\mathbf{x} \in B_1^d$ , 积分 (8.2.7) 可由 Riemann 和逼近, 即

$$\left| C' \int_{\mathbb{R}^d} q_{\mathbf{x}}(\boldsymbol{\xi}) d\mu(\boldsymbol{\xi}) - C' \sum_{\boldsymbol{\theta} \in \frac{1}{n}\mathbb{Z}^d} q_{\mathbf{x}}(\boldsymbol{\theta}) \mu(I_{\boldsymbol{\theta}}) \right| \rightarrow 0 \quad \text{当 } n \rightarrow \infty, \quad (8.2.9)$$

其中  $I_{\boldsymbol{\theta}} := [0, 1/n)^d + \boldsymbol{\theta}$ . 由于映射  $\mathbf{x} \mapsto f(\mathbf{x}) - f(\mathbf{0})$  连续, 从而在  $B_1^d$  上有界, 由控制收敛定理可得

$$\frac{1}{|B_1^d|} \int_{B_1^d} \left| f(\mathbf{x}) - f(\mathbf{0}) - C' \sum_{\boldsymbol{\theta} \in \frac{1}{n}\mathbb{Z}^d} q_{\mathbf{x}}(\boldsymbol{\theta}) \mu(I_{\boldsymbol{\theta}}) \right|^2 d\mathbf{x} \rightarrow 0. \quad (8.2.10)$$

由于  $\sum_{\boldsymbol{\theta} \in \frac{1}{n}\mathbb{Z}^d} \mu(I_{\boldsymbol{\theta}}) = \mu(\mathbb{R}^d) = 1$ , 断言成立.

**步骤 3.** 对每个  $\boldsymbol{\theta} \in \mathbb{R}^d$ , 证明映射  $\mathbf{x} \mapsto q_{\mathbf{x}}(\boldsymbol{\theta})$  属于  $G_C$  的凸组合在  $L^{2,\diamond}(B_1^d)$  中的闭包. 结合步骤 2, 这就完成证明.

令  $z = \langle \mathbf{x}, \boldsymbol{\theta} / |\boldsymbol{\theta}| \rangle$ . 若映射

$$\begin{aligned} h_{\boldsymbol{\theta}} : [-1, 1] &\rightarrow \mathbb{R}, \\ z &\mapsto C' \frac{\cos(|\boldsymbol{\theta}|z + \kappa(\boldsymbol{\theta})) - \cos(\kappa(\boldsymbol{\theta}))}{|\boldsymbol{\theta}|} \end{aligned} \quad (8.2.11)$$

能由下述形式的函数之凸组合任意精确地逼近, 结论即成立:

$$[-1, 1] \ni z \mapsto \gamma \mathbb{1}_{\mathbb{R}_+}(a'z + b'), \quad (8.2.12)$$

其中  $a', b' \in \mathbb{R}$  且  $|\gamma| \leq 2C$ . 为证明这一点, 对  $T \in \mathbb{N}$  定义

$$\begin{aligned} g_{T,+} &:= \sum_{i=1}^T \frac{|h_{\theta}(i/T) - h_{\theta}((i-1)/T)|}{2C} \\ &\quad \times (2C \operatorname{sign}(h_{\theta}(i/T) - h_{\theta}((i-1)/T)) \mathbb{1}_{\mathbb{R}_+}(x - i/T)), \\ g_{T,-} &:= \sum_{i=1}^T \frac{|h_{\theta}(-i/T) - h_{\theta}((1-i)/T)|}{2C} \\ &\quad \times (2C \operatorname{sign}(h_{\theta}(-i/T) - h_{\theta}((1-i)/T)) \mathbb{1}_{\mathbb{R}_+}(-x + i/T)). \end{aligned}$$

依构造,  $g_{T,-} + g_{T,+}$  是  $h_{\theta}$  的分段常数逼近, 并在  $i/T$  ( $i = 1, \dots, T$ ) 处插值  $h_{\theta}$ . 由于  $h_{\theta}$  连续, 当  $T \rightarrow \infty$  时有  $g_{T,-} + g_{T,+} \rightarrow h_{\theta}$  一致收敛. 此外,  $\|h'_{\theta}\|_{L^{\infty}(\mathbb{R})} \leq C$ , 故

$$\begin{aligned} &\sum_{i=1}^T \frac{|h_{\theta}(i/T) - h_{\theta}((i-1)/T)|}{2C} + \sum_{i=1}^T \frac{|h_{\theta}(-i/T) - h_{\theta}((1-i)/T)|}{2C} \\ &\leq \frac{2}{2CT} \sum_{i=1}^T \|h'_{\theta}\|_{L^{\infty}(\mathbb{R})} \leq 1, \end{aligned}$$

最后一个不等式使用了  $C' \leq C$ . 因而,  $g_{T,-} + g_{T,+}$  是式 (8.2.12) 所示函数的凸组合. 所以,  $h_{\theta}$  可以由式 (8.2.12) 形式的凸组合任意精确地逼近, 证明完毕.  $\square$

现在已经具备完成定理 8.12 证明所需的全部工具.

**定理 8.12 的证明:** 设  $f \in \Gamma_C$ . 由引理 8.15,

$$f|_{B_1^d} - f(\mathbf{0}) \in \overline{\operatorname{co}}(G_C),$$

其中闭包关于范数 (8.2.5) 而取. 容易看出, 对每个  $g \in G_C$  都有  $\|g\|_{L^{2,\diamond}(B_1^d)} \leq 2C$ . 将引理 8.14 用于 Hilbert 空间  $L^{2,\diamond}(B_1^d)$ , 可知对每个  $N \in \mathbb{N}$ , 存在  $|\gamma_i| \leq 2C$ 、 $\mathbf{a}_i \in \mathbb{R}^d$ 、 $b_i \in \mathbb{R}$  ( $i = 1, \dots, N$ ), 使得

$$\frac{1}{|B_1^d|} \int_{B_1^d} \left| f(\mathbf{x}) - f(\mathbf{0}) - \frac{1}{N} \sum_{i=1}^N \gamma_i \mathbb{1}_{\mathbb{R}_+}(\langle \mathbf{a}_i, \mathbf{x} \rangle + b_i) \right|^2 d\mathbf{x} \leq \frac{4C^2}{N}.$$

由习题 3.26, 当  $\lambda \rightarrow \infty$  时,  $\sigma(\lambda \cdot) \rightarrow \mathbb{1}_{\mathbb{R}_+}$  几乎处处成立. 因而, 对每个  $\delta > 0$ , 存在  $\tilde{\mathbf{a}}_i$ 、 $\tilde{b}_i$  ( $i = 1, \dots, N$ ), 使得

$$\frac{1}{|B_1^d|} \int_{B_1^d} \left| f(\mathbf{x}) - f(\mathbf{0}) - \frac{1}{N} \sum_{i=1}^N \gamma_i \sigma(\langle \tilde{\mathbf{a}}_i, \mathbf{x} \rangle + \tilde{b}_i) \right|^2 d\mathbf{x} \leq \frac{4C^2}{N} + \delta.$$

注意到

$$\frac{1}{N} \sum_{i=1}^N \gamma_i \sigma(\langle \tilde{\mathbf{a}}_i, \mathbf{x} \rangle + \tilde{b}_i) + f(\mathbf{0})$$

是架构为  $(\sigma; d, N, 1)$  的神经网络, 即得结论.  $\square$



定理 8.12 中与维数无关的逼近率或许令人惊讶，尤其是与第 4 章和第 5 章的结果相比。不过，只要认识到有限 Fourier 矩这一假设实际上是一种依赖维数的正则性假设，就能解释这一点。的确，该条件在更高维数下限制更强，因此  $\Gamma_C$  的复杂度不随维数增长。

为进一步说明这一点，我们把 Barron 类与经典函数空间联系起来。文献 [17, Section II] 指出，一个充分条件是阶数不超过  $\lfloor d/2 \rfloor + 2$  的所有导数均平方可积。换言之，若  $f$  属于 Sobolev 空间  $H^{\lfloor d/2 \rfloor + 2}(\mathbb{R}^d)$ ，则  $f$  是 Barron 函数。重要的是，维数越高，函数必须越光滑。这一假设也能推出：由至多  $N$  个 B 样条之和在  $L^2$  范数下逼近时，逼近率为  $N^{-1/2}$ ，见文献 [230, 82]。不过，在这类估计中，某些常数仍可能指数依赖于  $d$ ；而定理 8.12 中的所有常数都独立于  $d$  地受到控制。

Barron 函数逼近的另一个显著特点是，除输出权重外，其余权重的绝对值不受常数控制。为说明这一点，参见式 (8.2.9)，其中需要使用任意大的  $\theta$ 。虽然  $\Gamma_C$  是紧集，但对固定  $N \in \mathbb{N}$ ，指定架构的神经网络集合并非由紧参数集参数化。在某种意义上，这使人联想到命题 3.20 和定理 3.21：其中通过使用非常复杂的激活函数和非紧参数空间，实现了任意强的逼近率。

### 8.3 具有复合结构的函数

作为另一类能够克服维数灾难的函数，我们研究具有复合结构的函数 (functions with compositional structure)。直观地说，这类高维函数由许多低维函数复合而成。这一观点由文献 [244] 提出。在许多情形下，这可以是切合实际的假设，例如在传感器网络中，局部信息先在较小的传感器簇中汇总，再把部分信息发送到处理单元作进一步评估。

下面引入复合函数的一个模型。考虑具有  $M$  个顶点  $\eta_1, \dots, \eta_M$  的有向无环图  $\mathcal{G}$ ，满足

- 恰有  $d$  个顶点  $\eta_1, \dots, \eta_d$  没有入边；
- 每个顶点至多有  $m \in \mathbb{N}$  条入边；
- 恰有一个顶点  $\eta_M$  没有出边。

对每个  $j > d$ ，给顶点  $\eta_j$  关联一个函数  $f_j: \mathbb{R}^{d_j} \rightarrow \mathbb{R}$ 。这里， $d_j$  是集合  $S_j$  的基数； $S_j$  定义为所有指标  $i$  的集合，其中顶点  $\eta_i$  到顶点  $\eta_j$  有一条边。不失一般性，假设对所有  $j > d$  都有  $m \geq d_j = |S_j| \geq 1$ 。最后，令

$$F_j := x_j \quad \text{对所有 } j \leq d, \quad (8.3.1a)$$

以及<sup>3</sup>

$$F_j := f_j((F_i)_{i \in S_j}) \quad \text{对所有 } j > d. \quad (8.3.1b)$$

---

<sup>3</sup>式 (8.3.1b) 中输入  $(F_i)_{i \in S_j}$  的次序是任意的，但在全文中视为固定。

于是  $F_M(x_1, \dots, x_d)$  是从  $\mathbb{R}^d$  到  $\mathbb{R}$  的函数. 假设

$$\|f_j\|_{C^{k,s}(\mathbb{R}^{d_j})} \leq 1 \quad \text{对所有 } j = d+1, \dots, M, \quad (8.3.2)$$

把所有这类  $F_M$  构成的集合记为  $\mathcal{F}^{k,s}(m, d, M)$ . 图 8.2 展示了这类函数可能采用的图结构.

显然, 当  $s = 0$  时,  $\mathcal{F}^{k,0}(m, d, M) \subseteq C^k(\mathbb{R}^d)$ , 因为  $C^k$  函数的复合仍属于  $C^k$ . 直接应用定理 7.11, 可以用规模为  $O(N \log N)$  的神经网络逼近  $F_M \in \mathcal{F}^k(m, d, M)$ , 误差为  $O(N^{-k/d})$ . 由于每个  $f_j$  只依赖  $m$  个变量, 直观上可期望  $O(N^{-k/m})$  型的误差收敛率, 其中常数以某种方式依赖于顶点数  $M$ . 为证明这确实可行, 下面给每个节点  $\eta_j$  关联一个深度  $l_j \geq 0$ , 定义为从  $\eta_j$  连接到节点  $\{\eta_1, \dots, \eta_d\}$  之一的最大边数.




图 8.2: 可作为复合函数基础的三类图. 相应函数仅由二元或三元函数复合而成.

**命题 8.16:** 设  $k, m, d, M \in \mathbb{N}$ ,  $s > 0$ , 并设  $F_M \in \mathcal{F}^{k,s}(m, d, M)$ . 则存在常数  $C = C(m, k + s, M)$ , 使得对每个  $N \in \mathbb{N}$ , 都存在 ReLU 神经网络  $\Phi^{F_M}$ , 满足

$$\text{size}(\Phi^{F_M}) \leq CN \log N, \quad \text{depth}(\Phi^{F_M}) \leq C \log N,$$

以及

$$\sup_{\mathbf{x} \in [0,1]^d} |F_M(\mathbf{x}) - \Phi^{F_M}(\mathbf{x})| \leq N^{-(k+s)/m}.$$

**证明:** 在整个证明中, 不失一般性地假设各指标服从一个拓扑排序, 即对所有  $j$  都有  $S_j \subseteq \{1, \dots, j-1\}$  (也就是说, 顶点  $\eta_j$  的输入只能是满足  $i < j$  的顶点  $\eta_i$ ).

**步骤 1.** 首先假设存在函数  $\hat{f}_j$ , 使得对  $0 < \varepsilon \leq 1$ ,

$$|f_j(\mathbf{x}) - \hat{f}_j(\mathbf{x})| \leq \delta_j := \varepsilon(2m)^{-(M+1-j)} \quad \text{对所有 } \mathbf{x} \in [-2, 2]^{d_j}. \quad (8.3.3)$$

按式 (8.3.1) 定义  $\hat{F}_j$ , 但把式 (8.3.1b) 中的所有  $f_j$  换成  $\hat{f}_j$ . 现在估计  $\hat{F}_M$  对  $F_M$  的逼近误差. 为此, 对  $j$  作归纳, 证明对所有  $\mathbf{x} \in [-1, 1]^d$ ,

$$|F_j(\mathbf{x}) - \hat{F}_j(\mathbf{x})| \leq (2m)^{-(M-j)} \varepsilon. \quad (8.3.4)$$

注意, 由  $\|f_j\|_{C^k} \leq 1$  可知  $|F_j(\mathbf{x})| \leq 1$ , 因此式 (8.3.4) 特别蕴含  $\widehat{F}_j(\mathbf{x}) \in [-2, 2]$ .

当  $j = 1$  时,  $F_1(x_1) = \widehat{F}_1(x_1) = x_1$ , 故式 (8.3.4) 对所有  $x_1 \in [-1, 1]$  成立. 对归纳步骤, 由式 (8.3.3) 及归纳假设, 对所有  $\mathbf{x} \in [-1, 1]^d$ ,

$$\begin{aligned} |F_j(\mathbf{x}) - \widehat{F}_j(\mathbf{x})| &= |f_j((F_i)_{i \in S_j}) - \widehat{f}_j((\widehat{F}_i)_{i \in S_j})| \\ &= |f_j((F_i)_{i \in S_j}) - f_j((\widehat{F}_i)_{i \in S_j})| + |f_j((\widehat{F}_i)_{i \in S_j}) - \widehat{f}_j((\widehat{F}_i)_{i \in S_j})| \\ &\leq \sum_{i \in S_j} |F_i - \widehat{F}_i| + \delta_j \\ &\leq m(2m)^{-(M-(j-1))\varepsilon} + (2m)^{-(M+1-j)\varepsilon} \\ &\leq (2m)^{-(M-j)\varepsilon}. \end{aligned}$$

这里使用了: 对所有  $r \in S_j$ ,  $|\frac{d}{dx_r} f_j((x_i)_{i \in S_j})| \leq 1$ . 因而, 由三角不等式和中值定理,

$$\begin{aligned} &|f_j((x_i)_{i \in S_j}) - f_j((y_i)_{i \in S_j})| \\ &\leq \sum_{r \in S_j} \left| f((x_i)_{i \in S_j}, (y_i)_{i \in S_j}) - f((x_i)_{i < r}, (y_i)_{i \geq r}) \right| \\ &\leq \sum_{r \in S_j} |x_r - y_r|. \end{aligned}$$

这证明了式 (8.3.4), 从而对所有  $\mathbf{x} \in [-1, 1]^d$ ,

$$|F_M(\mathbf{x}) - \widehat{F}_M(\mathbf{x})| \leq \varepsilon.$$

**步骤 2.** 下面概述如何把步骤 1 中的  $\widehat{F}_M$  写成满足所述规模和深度界的神经网络  $\Phi^{F_M}$ . 固定  $N \in \mathbb{N}$ , 令

$$N_j := \left\lceil N(2m)^{\frac{m}{k+s}(M+1-j)} \right\rceil.$$

由定理 7.11 及  $d_j \leq m$ , 可找到神经网络  $\Phi^{f_j}$ , 满足

$$\sup_{\mathbf{x} \in [-2, 2]^{d_j}} |f_j(\mathbf{x}) - \Phi^{f_j}(\mathbf{x})| \leq N_j^{-(k+s)/m} \quad (8.3.5)$$

$$\leq N^{-(k+s)/m} (2m)^{-(M+1-j)}, \quad (8.3.6)$$

并且

$$\begin{aligned} \text{size}(\Phi^{f_j}) &\leq CN_j \log N_j \\ &\leq CN(2m)^{\frac{m(M+1-j)}{k+s}} \left( \log N + \log(2m)^{\frac{m(M+1-j)}{k+s}} \right), \end{aligned}$$

以及

$$\text{depth}(\Phi^{f_j}) \leq C \left( \log N + \log(2m)^{\frac{m(M+1-j)}{k+s}} \right).$$

于是

$$\begin{aligned}
\sum_{j=1}^M \text{size}(\Phi^{f_j}) &\leq 2CN \log N \sum_{j=1}^M (2m)^{\frac{m(M+1-j)}{k+s}} \\
&\leq 2CN \log N \sum_{j=1}^M \left( (2m)^{\frac{m}{k+s}} \right)^j \\
&\leq 2CN \log N (2m)^{\frac{m(M+1)}{k+s}}.
\end{aligned}$$

这里使用了

$$\sum_{j=1}^M a^j \leq \int_1^{M+1} \exp(\log(a)x) dx \leq \frac{1}{\log a} a^{M+1}.$$

由式 (8.3.3) 和 (8.3.5), 步骤 1 中的函数  $\hat{F}_M$  将给出误差  $N^{-(k+s)/m}$ . 我们注意到, 可以把  $\hat{F}_M$  归纳构造造成神经网络  $\Phi^{F_M}$ : 先利用恒等神经网络把所有值  $\Phi^{F_1}, \dots, \hat{\Phi}^{F_j}$  传递到所有后续层, 再把  $(\Phi^{F_i})_{i \in S_{j+1}}$  的输出作为  $\Phi^{f_{j+1}}$  的输入. 该神经网络的深度满足

$$\sum_{j=1}^M \text{depth}(\Phi^{f_j}) = O(M \log N).$$

至多有  $\sum_{j=1}^M |S_j| \leq mM$  个值需要在这  $O(M \log N)$  层中传递, 恒等神经网络由此带来的开销为  $O(mM^2 \log N) = O(\log N)$ . 因而, 神经网络的总规模为  $O(N \log N)$ .  $\square$

**注 8.17:** 从证明可见, 命题 8.16 中的常数  $C$  具有  $O((2m)^{\frac{m(M+1)}{k+s}})$  型行为.  $\diamond$

## 8.4 流形上的函数

另一种能够缓解维数灾难的情形是: 网络输入虽然属于  $\mathbb{R}^d$ , 但来自一个  $m$  维流形  $\mathcal{M} \subseteq \mathbb{R}^d$ . 如果只在  $\mathcal{M}$  上度量逼近误差, 那么仍可证明决定收敛率的是  $m$  而非  $d$ .

为说明这一思路, 下面假设  $\mathcal{M}$  是  $\mathbb{R}^d$  中光滑、紧的  $m$  维流形. 进一步假设存在  $\delta > 0$  及有限多个点  $\mathbf{x}_1, \dots, \mathbf{x}_M \in \mathcal{M}$ , 使得  $\delta$ -球

$$B_{\delta/2}(\mathbf{x}_i) := \{\mathbf{y} \in \mathbb{R}^d \mid \|\mathbf{y} - \mathbf{x}_i\|_2 < \delta/2\}, \quad j = 1, \dots, M,$$

覆盖  $\mathcal{M}$  (由于  $\mathcal{M}$  紧, 对每个  $\delta > 0$  都存在这样的  $\mathbf{x}_i$ ). 再以  $T_{\mathbf{x}}\mathcal{M} \simeq \mathbb{R}^m$  表示  $\mathcal{M}$  在  $\mathbf{x}$  处的切空间, 并假设  $\delta > 0$  足够小, 使正交投影

$$\pi_j : B_{\delta}(\mathbf{x}_j) \cap \mathcal{M} \rightarrow T_{\mathbf{x}_j}\mathcal{M} \tag{8.4.1}$$

是单射, 集合  $\pi_j(B_{\delta}(\mathbf{x}_j) \cap \mathcal{M}) \subseteq T_{\mathbf{x}_j}\mathcal{M}$  具有  $C^\infty$  边界, 并且  $\pi_j$  的逆映射

$$\pi_j^{-1} : \pi_j(B_{\delta}(\mathbf{x}_j) \cap \mathcal{M}) \rightarrow \mathcal{M} \tag{8.4.2}$$

属于  $C^\infty$  (这是可行的, 因为  $\mathcal{M}$  是光滑流形). 图 8.3 直观展示了这一假设.




图 8.3: 三维空间中的一维子流形. 在橙色点处画出了一个球以及该流形的切空间.

注意, 式 (8.4.1) 中的  $\pi_j$  是线性映射, 而式 (8.4.2) 中的  $\pi_j^{-1}$  一般是非线性的. 对函数  $f: \mathcal{M} \rightarrow \mathbb{R}$ , 可以写成

$$f(\mathbf{x}) = f(\pi_j^{-1}(\pi_j(\mathbf{x}))) = f_j(\pi_j(\mathbf{x})) \quad \text{对所有 } \mathbf{x} \in B_\delta(\mathbf{x}_j) \cap \mathcal{M}, \quad (8.4.3)$$

其中

$$f_j := f \circ \pi_j^{-1} : \pi_j(B_\delta(\mathbf{x}_j) \cap \mathcal{M}) \rightarrow \mathbb{R}.$$

下文中, 对  $f: \mathcal{M} \rightarrow \mathbb{R}$ 、 $k \in \mathbb{N}_0$  及  $s \in [0, 1)$ , 令

$$\|f\|_{C^{k,s}(\mathcal{M})} := \sup_{j=1,\dots,M} \|f_j\|_{C^{k,s}(\pi_j(B_\delta(\mathbf{x}_j) \cap \mathcal{M}))}.$$

现在陈述本节的主要结果.

**命题 8.18:** 设  $d, k \in \mathbb{N}$ 、 $s \geq 0$ , 并设  $\mathcal{M}$  是  $\mathbb{R}^d$  中光滑、紧的  $m$  维流形. 则存在常数  $C > 0$ , 使得对所有  $f \in C^{k,s}(\mathcal{M})$  和每个  $N \in \mathbb{N}$ , 都存在 ReLU 神经网络  $\Phi_N^f$ , 满足  $\text{size}(\Phi_N^f) \leq CN \log N$ 、 $\text{depth}(\Phi_N^f) \leq C \log N$ , 以及

$$\sup_{\mathbf{x} \in \mathcal{M}} |f(\mathbf{x}) - \Phi_N^f(\mathbf{x})| \leq C \|f\|_{C^{k,s}(\mathcal{M})} N^{-(k+s)/m}.$$

**证明:** 由于  $\mathcal{M}$  紧, 存在  $A > 0$  使  $\mathcal{M} \subseteq [-A, A]^d$ . 与定理 7.11 的证明类似, 考虑节点为  $\{-A + 2A_n^\nu | \nu \leq n\}$  的一致网格, 以及相应的分段线性基函数; 它们在  $[-A, A]^d$  上构成单位分解  $\sum_{\nu \leq n} \varphi_\nu \equiv 1$ , 其中

$$\text{supp } \varphi_\nu \subseteq \{\mathbf{y} \in \mathbb{R}^d \mid \|\frac{\boldsymbol{\nu}}{n} - \mathbf{y}\|_\infty \leq \frac{A}{n}\}.$$

令  $\delta > 0$  如本节开头所定. 由于  $(B_{\delta/2}(\mathbf{x}_j))_{j=1}^M$  覆盖  $\mathcal{M}$ , 固定足够大的  $n \in \mathbb{N}$  后, 对每个满足  $\text{supp } \varphi_\nu \cap \mathcal{M} \neq \emptyset$  的  $\nu$ , 都存在  $j(\nu) \in \{1, \dots, M\}$ , 使得  $\text{supp } \varphi_\nu \subseteq B_\delta(\mathbf{x}_{j(\nu)})$ . 令

$$I_j := \{\nu \leq n \mid j = j(\nu)\}.$$

使用式 (8.4.3), 对所有  $\mathbf{x} \in \mathcal{M}$  有

$$\begin{aligned} f(\mathbf{x}) &= \sum_{\nu \leq n} \varphi_\nu(\mathbf{x}) f(\mathbf{x}) \\ &= \sum_{j=1}^M \sum_{\nu \in I_j} \varphi_\nu(\mathbf{x}) f_j(\pi_j(\mathbf{x})). \end{aligned} \quad (8.4.4)$$

接下来逼近函数  $f_j$ . 令  $C_j$  为  $T_{\mathbf{x}_j} \mathcal{M} \simeq \mathbb{R}^m$  中包含  $\pi_j(B_\delta(\mathbf{x}_j) \cap \mathcal{M})$  的最小 ( $m$  维) 立方体. 函数  $f_j$  可以延拓到  $C_j$  上的函数 (该延拓仍记作  $f_j$ ), 并满足

$$\|f\|_{C^{k,s}(C_j)} \leq C \|f\|_{C^{k,s}(\pi_j(B_\delta(\mathbf{x}_j) \cap \mathcal{M}))},$$

其中常数依赖于  $\pi_j(B_\delta(\mathbf{x}_j) \cap \mathcal{M})$ , 但与  $f$  无关. 例如, 文献 [292, Chapter VI] 给出了这类延拓结果. 由定理 7.11 (另见注 7.12), 存在神经网络  $\hat{f}_j : C_j \rightarrow \mathbb{R}$ , 使得

$$\sup_{\mathbf{x} \in C_j} |f_j(\mathbf{x}) - \hat{f}_j(\mathbf{x})| \leq CN^{-(k+s)/m} \quad (8.4.5)$$

且

$$\text{size}(\hat{f}_j) \leq CN \log N, \quad \text{depth}(\hat{f}_j) \leq C \log N.$$

为逼近式 (8.4.4) 中的  $f$ , 令  $\varepsilon := N^{-(k+s)/m}$ , 并定义

$$\Phi_N := \sum_{j=1}^M \sum_{\nu \in I_j} \Phi_\varepsilon^\times(\varphi_\nu, \hat{f}_j \circ \pi_j).$$

注意到  $\pi_j$  是线性的, 故  $\hat{f}_j \circ \pi_j$  可以由神经网络表示. 首先估计这一逼近的误差. 对  $\mathbf{x} \in \mathcal{M}$ ,

$$\begin{aligned} |f(\mathbf{x}) - \Phi_N(\mathbf{x})| &\leq \sum_{j=1}^M \sum_{\nu \in I_j} \left| \varphi_\nu(\mathbf{x}) f_j(\pi_j(\mathbf{x})) - \Phi_\varepsilon^\times(\varphi_\nu(\mathbf{x}), \hat{f}_j(\pi_j(\mathbf{x}))) \right| \\ &\leq \sum_{j=1}^M \sum_{\nu \in I_j} \left( \left| \varphi_\nu(\mathbf{x}) f_j(\pi_j(\mathbf{x})) - \varphi_\nu(\mathbf{x}) \hat{f}_j(\pi_j(\mathbf{x})) \right| \right. \\ &\quad \left. + \left| \varphi_\nu(\mathbf{x}) \hat{f}_j(\pi_j(\mathbf{x})) - \Phi_\varepsilon^\times(\varphi_\nu(\mathbf{x}), \hat{f}_j(\pi_j(\mathbf{x}))) \right| \right) \\ &\leq \sup_{i \leq M} \|f_i - \hat{f}_i\|_{L^\infty(C_i)} \sum_{j=1}^M \sum_{\nu \in I_j} |\varphi_\nu(\mathbf{x})| \\ &\quad + \sum_{j=1}^M \sum_{\{\nu \in I_j \mid \mathbf{x} \in \text{supp } \varphi_\nu\}} \varepsilon \\ &\leq CN^{-(k+s)/m} + d\varepsilon \leq CN^{-(k+s)/m}, \end{aligned}$$

其中使用了  $\mathbf{x}$  至多属于  $d$  个  $\varphi_\nu$  的支集, 且  $C$  是依赖于  $d$  和  $\mathcal{M}$  的常数.

最后估计该逼近的规模和深度. 使用  $\text{size}(\varphi_\nu) \leq C$ 、 $\text{depth}(\varphi_\nu) \leq C$  (见式 (5.3.12)), 以及  $\text{size}(\Phi_\varepsilon^\times) \leq C \log \varepsilon \leq C \log N$  和  $\text{depth}(\Phi_\varepsilon^\times) \leq C \text{depth}(\varepsilon) \leq C \log N$  (见引理 7.3), 得到

$$\begin{aligned} & \sum_{j=1}^M \sum_{\nu \in I_j} \left( \text{size}(\Phi_\varepsilon^\times) + \text{size}(\varphi_\nu) + \text{size}(\hat{f}_i \circ \pi_j) \right) \\ & \leq \sum_{j=1}^M \sum_{\nu \in I_j} (C \log N + C + CN \log N) \\ & = O(N \log N), \end{aligned}$$

这蕴含  $\text{size}(\Phi_N)$  的界. 此外,

$$\begin{aligned} \text{depth}(\Phi_N) & \leq \text{depth}(\Phi_\varepsilon^\times) + \max\{\text{depth}(\varphi_\nu, \hat{f}_j)\} \\ & \leq C \log N + \log N = O(\log N). \end{aligned}$$

证明完毕. □

## 文献与延伸阅读

第 8.1 节关于维数灾难的内容基于文献 [82, 223]. 特别地, 定理 8.1 和 8.4 是文献 [82] 中结果的简化版本; 定理 8.10 则是文献 [223] 主要结果的一个变体, 后者对  $W$  采用了不同假设 (假设其各分量是有界线性映射). 不过, 论证的主要部分完全相同, 其他陈述的证明也紧随这些参考文献. 这一方向的其他相关文献例如 [165, 241, 81, 240, 222].

第 8.2 节的思想最初由文献 [17] 提出, 文献 [16] 把它推广到  $L^\infty$  逼近. 当不连续性沿着 Barron 函数发生时, 这些论证还可推广到高维不连续函数, 并给出与维数无关的逼近率, 见文献 [238]. Barron 类已有多种推广, 参见文献 [191, 190, 322, 323, 19].

第 8.3 节的复合性假设采用文献 [244] 所讨论的形式. 文献 [164] 研究了另一种称为层级复合/交互模型的方法.

第 8.4 节讨论的流形假设经常见于文献, 代表性例子包括 [284, 65, 58, 275, 211, 163].

本章略去的另一个重要方向是科学机器学习. 高维函数常常来自 (参数化) 偏微分方程, 而关于其性质与结构已有丰富文献. 多项结果表明, 神经网络能够利用这类问题中已知存在的内在低维性. 基于文献 [332], 文献 [280, 281] 验证了对参数化偏微分方程中普遍出现的某些高维、甚至无限维解析函数类进行高效逼近的结果. 关于高维参数问题的进一步一般分析见文献 [229, 169]; 利用底层偏微分方程特定结构条件的结果例如见文献 [172, 267]. 此外, 文献 [88, 204, 228] 给出了某些光滑函数在可能很高但有限的维数下快速收敛的结果.

关于高维偏微分方程, 文献 [116] 处理了椭圆问题; 文献 [117, 109, 141] 研究了线性与半线性抛物型演化方程; 随机微分方程则见文献 [150].



## 习题

8.19. 设  $C > 0$ 、 $d \in \mathbb{N}$ . 证明: 若  $g \in \Gamma_C$ , 则对每个  $a \in \mathbb{R}_+$ 、 $\mathbf{b} \in \mathbb{R}^d$ , 都有

$$a^{-d}g(a(\cdot - \mathbf{b})) \in \Gamma_C.$$

8.20. 设  $C > 0$ 、 $d \in \mathbb{N}$ . 证明: 若  $g_i \in \Gamma_C$  ( $i = 1, \dots, m$ ), 且  $c = (c_i)_{i=1}^m$ , 则

$$\sum_{i=1}^m c_i g_i \in \Gamma_{\|c\|_1 C}.$$

8.21. 证明: 对每个  $d \in \mathbb{N}$ , 函数

$$f(\mathbf{x}) := \exp\left(-\frac{\|\mathbf{x}\|_2^2}{2}\right), \quad \mathbf{x} \in \mathbb{R}^d,$$

属于  $\Gamma_d$ , 并且当  $d \rightarrow \infty$  时有  $C_f = O(\sqrt{d})$ .

8.22. 设  $d \in \mathbb{N}$ , 且对  $\mathbf{x} \in \mathbb{R}^d$ , 令

$$f(\mathbf{x}) = \sum_{i=1}^{\infty} c_i \sigma_{\text{ReLU}}(\langle \mathbf{a}_i, \mathbf{x} \rangle + b_i),$$

其中对所有  $i \in \mathbb{N}$  都有  $\|\mathbf{a}_i\| = 1$ 、 $|b_i| \leq 1$ . 证明: 对每个  $N \in \mathbb{N}$ , 都存在具有  $N$  个神经元和一个隐藏层的 ReLU 神经网络  $f_N$ , 使得

$$\|f - f_N\|_{L^2(B_1^d)} \leq \frac{3\|c\|_1}{\sqrt{N}}.$$

因而, 每个无限 ReLU 神经网络都能以速率  $O(N^{1/2})$  由宽度为  $N$  的有限 ReLU 神经网络逼近.

8.23. 设  $C > 0$ . 证明每个  $f \in \Gamma_C$  都连续可微.

# 插值

与式 (1.3) 中经验风险最小化相联系的学习问题，是最小化在一个有限（训练）点集上计算神经网络所得的误差。与之相反，前面所有逼近结果都着眼于在整个定义域上取得一致的小误差。要找到训练误差很小的神经网络，似乎要容易得多：对于一系列神经网络  $\Phi_n$ ，不再需要  $\|f - \Phi_n\|_\infty \rightarrow 0$ ，只需对训练集中的所有  $\mathbf{x}_i$  有  $\Phi_n(\mathbf{x}_i) \rightarrow f(\mathbf{x}_i)$ 。

本章研究上述逼近问题的极端情形。我们分析在什么条件下，可以找到一个在所有训练点上都与目标函数  $f$  一致的神经网络。这称为插值（interpolation）。为精确定义这一概念，给出如下定义。

**定义 9.1 (插值):** 设  $d, m \in \mathbb{N}$ ，且  $\Omega \subseteq \mathbb{R}^d$ 。若对每个满足  $\mathbf{x}_i \neq \mathbf{x}_j$  ( $i \neq j$ ) 的  $S = (\mathbf{x}_i, y_i)_{i=1}^m \subseteq \Omega \times \mathbb{R}$ ，都存在函数  $h \in \mathcal{H}$ ，使得对所有  $i = 1, \dots, m$  都有  $h(\mathbf{x}_i) = y_i$ ，则称函数集  $\mathcal{H} \subseteq \{h: \Omega \rightarrow \mathbb{R}\}$  可插值  $\Omega$  中的  $m$  个点。

了解一种架构的插值性质极有价值，原因有二：

- 考虑一种可插值  $m$  个点的架构，并设训练样本数不超过  $m$ 。则式 (1.3) 总有解。
- 再考虑一种可插值  $m$  个点的架构，并设训练样本数小于  $m$ 。则对训练集外的每个点  $\tilde{\mathbf{x}}$  和每个  $y \in \mathbb{R}$ ，式 (1.3) 都存在满足  $h(\tilde{\mathbf{x}}) = y$  的极小化子  $h$ 。因而，若无进一步限制（其中许多将在后文讨论），这种架构一般无法泛化到未见数据。

插值问题有解并不能由前几章的逼近结果平凡地推出（尽管稍后将看到二者联系密切）。还要指出，给定架构的神经网络能够插值多少个点，与所谓 VC 维密切相关；我们将在第 14 章研究它。

下一节先给出一个与万能逼近定理相似、但针对插值的结果，由此开始分析神经网络的插值性质。随后一节再考察具有良好性质的插值。

## 9.1 万能插值

对激活函数和架构施加什么条件，才能使一组神经网络插值  $m \in \mathbb{N}$  个点？由第 3 章，特别是定理 3.9 可知，只要神经网络宽度足够大，浅层神经网络就能以任意精度逼近每个连续函数。随着网络宽度和/或深度增加，架构的能力不断增强，容易使人期待它最终应能插值  $m$  个点。然而，这一直觉未必正确：

**例 9.2:** 令  $\mathcal{H} := \{f \in C^0([0, 1]) \mid f(0) \in \mathbb{Q}\}$ 。则  $\mathcal{H}$  在  $C^0([0, 1])$  中稠密，却连  $[0, 1]$  中的一个点也不能插值。◇

此外，定理 3.9 是一个渐近结果，只说明对充分大的神经网络架构可以逼近给定函数，却没有说明架构究竟需要多大。

令人惊讶的是，定理 3.9 仍可用来保证：一个固定规模架构所产生的神经网络集能够插值  $m$  个点. 该结果来自文献 [240]；更详细的早期结果讨论见章末文献部分. 由于它与万能逼近定理相似且采用相同假设，我们称下述定理为“万能插值定理”. 陈述中需要回顾式 (3.1) 所定义的允许激活函数集合  $\mathcal{M}$ ，以及定义 3.7 中引入的宽度为  $n$  的浅层神经网络类  $\mathcal{N}_d^1(\sigma, 1, n)$ .

**定理 9.3** (万能插值定理): 设  $d, n \in \mathbb{N}$ ，且  $\sigma \in \mathcal{M}$  不是多项式. 则  $\mathcal{N}_d^1(\sigma, 1, n)$  可插值  $\mathbb{R}^d$  中的  $n+1$  个点.

**证明:** 任意固定  $(\mathbf{x}_i)_{i=1}^{n+1} \subseteq \mathbb{R}^d$ . 我们将证明，对任意  $(y_i)_{i=1}^{n+1} \subseteq \mathbb{R}$ ，都存在权重与偏置  $(\mathbf{w}_j)_{j=1}^n \subseteq \mathbb{R}^d$ 、 $(b_j)_{j=1}^n$ 、 $(v_j)_{j=1}^n \subseteq \mathbb{R}$  和  $c \in \mathbb{R}$ ，使得

$$\Phi(\mathbf{x}_i) := \sum_{j=1}^n v_j \sigma(\mathbf{w}_j^\top \mathbf{x}_i + b_j) + c = y_i \quad \text{对所有 } i = 1, \dots, n+1. \quad (9.1.1)$$

由于  $\Phi \in \mathcal{N}_d^1(\sigma, 1, n)$ ，这便能完成证明.

记

$$\mathbf{A} := \begin{pmatrix} 1 & \sigma(\mathbf{w}_1^\top \mathbf{x}_1 + b_1) & \cdots & \sigma(\mathbf{w}_n^\top \mathbf{x}_1 + b_n) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \sigma(\mathbf{w}_1^\top \mathbf{x}_{n+1} + b_1) & \cdots & \sigma(\mathbf{w}_n^\top \mathbf{x}_{n+1} + b_n) \end{pmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}. \quad (9.1.2)$$

若  $\mathbf{A}$  正则，则对每个  $(y_i)_{i=1}^{n+1}$ ，都存在  $c$  和  $(v_j)_{j=1}^n$  使式 (9.1.1) 成立. 因此，只需找到  $(\mathbf{w}_j)_{j=1}^n$  和  $(b_j)_{j=1}^n$  使  $\mathbf{A}$  正则.

为此，对  $k = 0, \dots, n$  作归纳，证明存在  $(\mathbf{w}_j)_{j=1}^k$  和  $(b_j)_{j=1}^k$ ，使  $\mathbf{A}$  的前  $k+1$  列线性无关.  $k=0$  的情形显然. 接着设  $0 < k < n$ ，并假设  $\mathbf{A}$  的前  $k$  列线性无关. 我们希望找到  $\mathbf{w}_k, b_k$ ，使前  $k+1$  列线性无关. 假设不存在这样的  $\mathbf{w}_k, b_k$ ，并令  $Y_k \subseteq \mathbb{R}^{n+1}$  为  $\mathbf{A}$  前  $k$  列张成的空间. 那么，对所有  $\mathbf{w} \in \mathbb{R}^n$ 、 $b \in \mathbb{R}$ ，向量  $(\sigma(\mathbf{w}^\top \mathbf{x}_i + b))_{i=1}^{n+1} \in \mathbb{R}^{n+1}$  都必须属于  $Y_k$ . 固定  $\mathbf{y} = (y_i)_{i=1}^{n+1} \in \mathbb{R}^{n+1} \setminus Y_k$ . 则

$$\begin{aligned} \inf_{\tilde{\Phi} \in \mathcal{N}_d^1(\sigma, 1)} \|(\tilde{\Phi}(\mathbf{x}_i))_{i=1}^{n+1} - \mathbf{y}\|_2^2 &= \inf_{N, \mathbf{w}_j, b_j, v_j, c} \sum_{i=1}^{n+1} \left( \sum_{j=1}^N v_j \sigma(\mathbf{w}_j^\top \mathbf{x}_i + b_j) + c - y_i \right)^2 \\ &\geq \inf_{\tilde{\mathbf{y}} \in Y_k} \|\tilde{\mathbf{y}} - \mathbf{y}\|_2^2 > 0. \end{aligned}$$

另一方面，可以找到连续函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，使得对所有  $i = 1, \dots, n+1$  都有  $f(\mathbf{x}_i) = y_i$ ；这与定理 3.9 矛盾.  $\square$

## 9.2 最优插值与重建

考虑有界区域  $\Omega \subseteq \mathbb{R}^d$ 、函数  $f: \Omega \rightarrow \mathbb{R}$ 、互异点  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \Omega$  以及相应函数值  $y_i := f(\mathbf{x}_i)$ . 我们的目标是仅依据数据对  $(\mathbf{x}_i, y_i)$  ( $i = 1, \dots, m$ ) 逼近  $f$ . 本节将说明，在对  $f$  作某些假设时，ReLU 神经网络可以表示一种“最优”重建，并且它还是数据的插值函数.

### 9.2.1 动机

上一节已经看到，对每个合理的激活函数，具有  $m - 1 \in \mathbb{N}$  个隐藏神经元的神经网络都能插值  $m$  个点。然而，并非所有插值函数都同样适合给定应用。例如，图 9.1 比较了单位区间上的多项式插值与分段仿射插值。




图 9.1: 用七次多项式和分段仿射样条插值八个点。多项式插值函数的导数或 Lipschitz 常数显著大于分段仿射插值函数。

这两个插值函数表现出很不相同的行为。一般而言，无法判定哪一个能更好地逼近  $f$ 。尤其是，关于  $f$  的信息有限，我们无法准确重建插值点  $\mathbf{x}_1, \dots, \mathbf{x}_m$  之间可能存在的任何额外特征。按照 Occam 剃刀原则，假设  $f$  在插值点之间不会剧烈振荡或表现反常，似乎是合理的。因而，在这一情形下分段插值函数看起来更可取。将  $f$  不“剧烈振荡”这一假设形式化的一种方式，是假设  $f$  的 Lipschitz 常数 (Lipschitz constant)

$$\text{Lip}(f) := \sup_{\mathbf{x} \neq \mathbf{y}} \frac{|f(\mathbf{x}) - f(\mathbf{y})|}{\|\mathbf{x} - \mathbf{y}\|} \quad (9.2.1)$$

由某个固定值  $M \in \mathbb{R}$  控制。这里  $\|\cdot\|$  表示  $\mathbb{R}^d$  上任意固定的范数。

应当如何选择  $M$ ？对每个满足

$$f(\mathbf{x}_i) = y_i \quad \text{对所有 } i = 1, \dots, m \quad (9.2.2)$$

的函数  $f: \Omega \rightarrow \mathbb{R}$ ，都有

$$\text{Lip}(f) = \sup_{\mathbf{x} \neq \mathbf{y} \in \Omega} \frac{|f(\mathbf{x}) - f(\mathbf{y})|}{\|\mathbf{x} - \mathbf{y}\|} \geq \sup_{i \neq j} \frac{|y_i - y_j|}{\|\mathbf{x}_i - \mathbf{x}_j\|} =: \widetilde{M}. \quad (9.2.3)$$

因此，在后续分析中固定实数  $M \geq \widetilde{M}$ 。

### 9.2.2 Lipschitz 连续函数的最优重建

上述讨论提出了如下问题：如果只知道函数的 Lipschitz 常数至多为  $M$ ，那么依据数据得到的  $f$  的最佳重建是什么？这里把“最佳重建”理解为在最坏情形下使  $L^\infty$  误差

最小的函数. 具体地, 令

$$\text{Lip}_M(\Omega) := \{f : \Omega \rightarrow \mathbb{R} \mid \text{Lip}(f) \leq M\} \quad (9.2.4)$$

表示 Lipschitz 常数至多为  $M$  的所有函数之集, 我们要解决如下问题: 求一个元素

$$\Phi \in \operatorname{argmin}_{h: \Omega \rightarrow \mathbb{R}} \sup_{\substack{f \in \text{Lip}_M(\Omega) \\ f \text{ 满足式 (9.2.2)}}} \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - h(\mathbf{x})|. \quad (9.2.5)$$

下一个定理说明, 式 (9.2.5) 中的函数  $\Phi$  确实存在. 它不仅具有显式公式, 而且属于  $\text{Lip}_M(\Omega)$  并插值给定数据. 因此, 它不只是最优重建, 也是最优插值函数. 该定理可追溯至文献 [23], 而后者又以文献 [297] 为基础.

**定理 9.4:** 设  $m, d \in \mathbb{N}$ ,  $\Omega \subseteq \mathbb{R}^d$ ,  $f : \Omega \rightarrow \mathbb{R}$ , 且  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \Omega$ ,  $y_1, \dots, y_m \in \mathbb{R}$  满足式 (9.2.2) 与式 (9.2.3), 其中  $\widetilde{M} > 0$ . 再设  $M \geq \widetilde{M}$ .

则式 (9.2.5) 中至少存在一个  $\Phi$ , 它由下式给出:

$$\Phi(\mathbf{x}) := \frac{1}{2}(f_{\text{upper}}(\mathbf{x}) + f_{\text{lower}}(\mathbf{x})) \quad \text{对 } \mathbf{x} \in \Omega, \quad (9.2.6)$$

其中

$$f_{\text{upper}}(\mathbf{x}) := \min_{k=1, \dots, m} (y_k + M\|\mathbf{x} - \mathbf{x}_k\|),$$

$$f_{\text{lower}}(\mathbf{x}) := \max_{k=1, \dots, m} (y_k - M\|\mathbf{x} - \mathbf{x}_k\|).$$

**证明:** 首先断言, 对所有  $h_1, h_2 \in \text{Lip}_M(\Omega)$ , 都有

$$\max\{h_1, h_2\} \in \text{Lip}_M(\Omega), \quad \min\{h_1, h_2\} \in \text{Lip}_M(\Omega).$$

由于  $\min\{h_1, h_2\} = -\max\{-h_1, -h_2\}$ , 只需证明最大值的断言. 即需验证, 对所有  $\mathbf{x} \neq \mathbf{y} \in \Omega$ ,

$$\frac{|\max\{h_1(\mathbf{x}), h_2(\mathbf{x})\} - \max\{h_1(\mathbf{y}), h_2(\mathbf{y})\}|}{\|\mathbf{x} - \mathbf{y}\|} \leq M. \quad (9.2.7)$$

固定  $\mathbf{x} \neq \mathbf{y}$ . 不失一般性, 设

$$\max\{h_1(\mathbf{x}), h_2(\mathbf{x})\} \geq \max\{h_1(\mathbf{y}), h_2(\mathbf{y})\}, \quad \max\{h_1(\mathbf{x}), h_2(\mathbf{x})\} = h_1(\mathbf{x}).$$

若  $\max\{h_1(\mathbf{y}), h_2(\mathbf{y})\} = h_1(\mathbf{y})$ , 则式 (9.2.7) 的分子等于  $h_1(\mathbf{x}) - h_1(\mathbf{y})$ , 它不超过  $M\|\mathbf{x} - \mathbf{y}\|$ . 若  $\max\{h_1(\mathbf{y}), h_2(\mathbf{y})\} = h_2(\mathbf{y})$ , 则该分子等于  $h_1(\mathbf{x}) - h_2(\mathbf{y})$ , 它不超过  $h_1(\mathbf{x}) - h_1(\mathbf{y}) \leq M\|\mathbf{x} - \mathbf{y}\|$ . 两种情形下式 (9.2.7) 都成立.

显然, 对每个  $k = 1, \dots, m$ , 都有映射  $\mathbf{x} \mapsto y_k - M\|\mathbf{x} - \mathbf{x}_k\| \in \text{Lip}_M(\Omega)$ , 从而  $f_{\text{upper}}, f_{\text{lower}} \in \text{Lip}_M(\Omega)$ , 且  $\Phi \in \text{Lip}_M(\Omega)$ .

接着断言, 对所有满足式 (9.2.2) 的  $f \in \text{Lip}_M(\Omega)$ , 都有

$$f_{\text{lower}}(\mathbf{x}) \leq f(\mathbf{x}) \leq f_{\text{upper}}(\mathbf{x}) \quad \text{对所有 } \mathbf{x} \in \Omega. \quad (9.2.8)$$

这是因为, 对每个  $k \in \{1, \dots, m\}$  和  $\mathbf{x} \in \Omega$ ,

$$|y_k - f(\mathbf{x})| = |f(\mathbf{x}_k) - f(\mathbf{x})| \leq M \|\mathbf{x} - \mathbf{x}_k\|,$$

所以对所有  $\mathbf{x} \in \Omega$ ,

$$f(\mathbf{x}) \leq \min_{k=1, \dots, m} (y_k + M \|\mathbf{x} - \mathbf{x}_k\|), \quad f(\mathbf{x}) \geq \max_{k=1, \dots, m} (y_k - M \|\mathbf{x} - \mathbf{x}_k\|).$$

由于  $f_{\text{upper}}, f_{\text{lower}} \in \text{Lip}_M(\Omega)$  满足式 (9.2.2), 对每个  $h : \Omega \rightarrow \mathbb{R}$  都有

$$\begin{aligned} \sup_{\substack{f \in \text{Lip}_M(\Omega) \\ f \text{ 满足式 (9.2.2)}}} \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - h(\mathbf{x})| &\geq \sup_{\mathbf{x} \in \Omega} \max\{|f_{\text{lower}}(\mathbf{x}) - h(\mathbf{x})|, |f_{\text{upper}}(\mathbf{x}) - h(\mathbf{x})|\} \\ &\geq \sup_{\mathbf{x} \in \Omega} \frac{|f_{\text{lower}}(\mathbf{x}) - f_{\text{upper}}(\mathbf{x})|}{2}. \end{aligned} \quad (9.2.9)$$

此外, 由式 (9.2.8),

$$\begin{aligned} \sup_{\substack{f \in \text{Lip}_M(\Omega) \\ f \text{ 满足式 (9.2.2)}}} \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - \Phi(\mathbf{x})| &\leq \sup_{\mathbf{x} \in \Omega} \max\{|f_{\text{lower}}(\mathbf{x}) - \Phi(\mathbf{x})|, |f_{\text{upper}}(\mathbf{x}) - \Phi(\mathbf{x})|\} \\ &= \sup_{\mathbf{x} \in \Omega} \frac{|f_{\text{lower}}(\mathbf{x}) - f_{\text{upper}}(\mathbf{x})|}{2}. \end{aligned} \quad (9.2.10)$$

最后, 式 (9.2.9) 与式 (9.2.10) 说明  $\Phi$  是式 (9.2.5) 的一个解.  $\square$

图 9.2 给出了图 9.1 中插值问题的  $f_{\text{upper}}$ 、 $f_{\text{lower}}$  和  $\Phi$ , 而图 9.3 给出了一个二维例子.




图 9.2: 用最优 Lipschitz 插值函数插值图 9.1 中的点.

### 9.2.3 最优 ReLU 重建

到目前为止, 所有结果对  $\mathbb{R}^d$  上任意范数都成立. 对下一个定理, 我们限制到 1-范数  $\|\mathbf{x}\|_1 = \sum_{j=1}^d |x_j|$ . 利用定理 9.4 的显式公式, 下面将证明一个引人注目的结果: ReLU 神经网络能够精确表示一种最优重建 (即式 (9.2.5) 意义下的最优重建), 并且网络规模关于维数  $d$  与数据点数  $m$  的乘积线性增长. 此外, 证明是构造性的, 因而原则上无须训练便可显式构造该神经网络.

**定理 9.5** (最优 Lipschitz 重建): 设  $m, d \in \mathbb{N}$ ,  $\Omega \subseteq \mathbb{R}^d$ ,  $f: \Omega \rightarrow \mathbb{R}$ , 且  $\mathbf{x}_1, \dots, \mathbf{x}_m \in \Omega$ ,  $y_1, \dots, y_m \in \mathbb{R}$  满足式 (9.2.2) 与式 (9.2.3), 其中  $\bar{M} > 0$ . 再设  $M \geq \bar{M}$ , 并在式 (9.2.3) 和式 (9.2.4) 中取  $\|\cdot\| = \|\cdot\|_1$ .

则存在 ReLU 神经网络  $\Phi \in \text{Lip}_M(\Omega)$ , 它插值给定数据 (即满足式 (9.2.2)), 并且

$$\Phi \in \operatorname{argmin}_{h: \Omega \rightarrow \mathbb{R}} \sup_{\substack{f \in \text{Lip}_M(\Omega) \\ f \text{ 满足式 (9.2.2)}}} \sup_{\mathbf{x} \in \Omega} |f(\mathbf{x}) - h(\mathbf{x})|.$$

此外,  $\text{depth}(\Phi) = O(\log(m))$ 、 $\text{width}(\Phi) = O(dm)$ , 且  $\Phi$  的所有权重的绝对值都不超过  $\max\{M, \|\mathbf{y}\|_\infty\}$ .

**证明:** 只需证明式 (9.2.6) 中的函数能够由满足定理所述规模界的 ReLU 神经网络表示. 首先注意到, 实现 1-范数的 ReLU 神经网络十分简单. 对所有  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\|\mathbf{x}\|_1 = \sum_{i=1}^d (\sigma(x_i) + \sigma(-x_i)).$$

因此, 存在 ReLU 神经网络  $\Phi^{\|\cdot\|_1}$ , 使得对所有  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\text{width}(\Phi^{\|\cdot\|_1}) = 2d, \quad \text{depth}(\Phi^{\|\cdot\|_1}) = 1, \quad \Phi^{\|\cdot\|_1}(\mathbf{x}) = \|\mathbf{x}\|_1.$$

于是存在 ReLU 神经网络  $\Phi_k: \mathbb{R}^d \rightarrow \mathbb{R}$  ( $k = 1, \dots, m$ ), 使得

$$\text{width}(\Phi_k) = 2d, \quad \text{depth}(\Phi_k) = 1, \quad \Phi_k(\mathbf{x}) = y_k + M\|\mathbf{x} - \mathbf{x}_k\|_1$$

对所有  $\mathbf{x} \in \mathbb{R}^d$  成立. 利用第 5.1.3 节引入的神经网络并行化, 存在 ReLU 神经网络  $\Phi_{\text{all}} := (\Phi_1, \dots, \Phi_m): \mathbb{R}^d \rightarrow \mathbb{R}^m$ , 使得

$$\text{width}(\Phi_{\text{all}}) = 4md, \quad \text{depth}(\Phi_{\text{all}}) = 1,$$

并且

$$\Phi_{\text{all}}(\mathbf{x}) = (y_k + M\|\mathbf{x} - \mathbf{x}_k\|_1)_{k=1}^m \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^d.$$

利用引理 5.11, 可以找到 ReLU 神经网络  $\Phi_{\text{upper}}$ , 使得对所有  $\mathbf{x} \in \Omega$  都有  $\Phi_{\text{upper}} = f_{\text{upper}}(\mathbf{x})$ , 并且  $\text{width}(\Phi_{\text{upper}}) \leq \max\{16m, 4md\}$ 、 $\text{depth}(\Phi_{\text{upper}}) \leq 1 + \log(m)$ .

基本相同的构造给出具有相应性质的 ReLU 神经网络  $\Phi_{\text{lower}}$ . 再用引理 5.4 即可完成证明.  $\square$



## 文献与延伸阅读

本章所述万能插值定理来自文献 [240, Theorem 5.1]. 更早还有若干在更强假设下证明的插值结果: 文献 [271] 已经把插值性质与矩阵 (9.1.2) 的秩条件联系起来, 但没有给出关于激活函数的一般条件. 文献 [146] 在激活函数  $\sigma$  连续且单调不减, 并满足  $\lim_{x \rightarrow -\infty} \sigma(x) = 0$ 、 $\lim_{x \rightarrow \infty} \sigma(x) = 1$  的假设下建立了插值定理. 文献 [138] 进一步去掉了  $\sigma$  单调不减的假设.

第 9.2 节最优 Lipschitz 插值定理的主要思想来自文献 [23]. 文献 [149, Theorem 2.27] 也给出了 Lipschitz 插值函数的神经网络构造, 但它不是式 (9.2.5) 意义下的最优插值函数.

## 习题

9.6. 在定理 9.4 的假设下, 对  $x \in \Omega$  定义最近邻集合

$$I_x := \operatorname{argmin}_{i=1,\dots,m} \|x_i - x\|.$$

定义单最近邻分类器  $f_{\text{INN}}$  为

$$f_{\text{INN}}(x) = \frac{1}{2} \left( \min_{i \in I_x} y_i + \max_{i \in I_x} y_i \right).$$

令  $\Phi_M$  为式 (9.2.6) 中的函数. 证明: 对所有  $x \in \Omega$ ,

$$\Phi_M(x) \rightarrow f_{\text{INN}}(x) \quad \text{当 } M \rightarrow \infty.$$

9.7. 将定理 9.5 推广到  $\|\cdot\|_\infty$ -范数.

提示: 所得神经网络需要比定理 9.5 中的网络更深.




图 9.3: 式 (9.2.6) 插值方法的二维例子. 从左上到下依次为  $f_{\text{upper}}$ 、 $f_{\text{lower}}$  和  $\Phi$ . 插值点  $(x_i, y_i)_{i=1}^6$  用红色叉号标出.

# 神经网络训练

到目前为止，我们已经讨论了如何用神经网络表示和逼近某些函数类。深度学习的第二根支柱，是如何令神经网络拟合给定数据；也就是说，在固定架构后，如何找到合适的权重和偏置。这一任务等价于极小化某个所谓的目标函数（objective function），例如式 (1.3) 中的经验风险。本章始终将目标函数记为

$$F: \mathbb{R}^n \rightarrow \mathbb{R},$$

并把它理解为以  $\mathbb{R}^n$  中一个向量所收集的全部神经网络权重和偏置为自变量的函数。目标<sup>4</sup>是（近似地）确定一个极小化子（minimizer），即找到某个  $\mathbf{w}_* \in \mathbb{R}^n$ ，使得

$$F(\mathbf{w}_*) \leq F(\mathbf{w}) \quad \text{对所有 } \mathbf{w} \in \mathbb{R}^n.$$

标准方法主要包括（随机）梯度下降法的各种变体。本章将聚焦这些方法，讨论基于梯度的算法在凸优化中的基本思想与结果。第 10.1、10.2 和 10.3 节分别研究梯度下降法、随机梯度下降法和加速梯度下降法，并对光滑、强凸目标函数给出收敛性证明。第 10.4 节讨论自适应步长，并解释 Adam 等常用算法背后的核心原理。最后，第 10.5 节介绍反向传播算法，它使基于梯度的方法能够高效地用于神经网络训练。

## 10.1 梯度下降法

梯度下降法的一般思想是从某个  $\mathbf{w}_0 \in \mathbb{R}^n$  出发，随后沿目标函数的最速下降方向逐次更新。暂设  $F \in C^2(\mathbb{R}^n)$ ，并用  $\mathbf{w}_k$  表示第  $k$  个迭代点。则

$$F(\mathbf{w}_k + \mathbf{v}) = F(\mathbf{w}_k) + \mathbf{v}^\top \nabla F(\mathbf{w}_k) + O(\|\mathbf{v}\|^2) \quad \text{当 } \|\mathbf{v}\| \rightarrow 0. \quad (10.1.1)$$

这说明  $\mathbf{w}_k$  附近  $F$  的变化由梯度  $\nabla F(\mathbf{w}_k)$  局部刻画。当  $\mathbf{v}$  很小时，二阶项的贡献可以忽略，使目标函数下降最多的方向  $\mathbf{v}$  等于负梯度  $-\nabla F(\mathbf{w}_k)$ 。因此， $-\nabla F(\mathbf{w}_k)$  也称为最速下降方向。由此得到如下更新：

$$\mathbf{w}_{k+1} := \mathbf{w}_k - h_k \nabla F(\mathbf{w}_k), \quad (10.1.2)$$

其中  $h_k > 0$  称为步长（step size）或学习率（learning rate）。我们称这一迭代算法为梯度下降法（gradient descent）。

由式 (10.1.1) 和式 (10.1.2)（另见文献 [34, Section 1.2]），有

$$F(\mathbf{w}_{k+1}) = F(\mathbf{w}_k) - h_k \|\nabla F(\mathbf{w}_k)\|^2 + O(h_k^2), \quad (10.1.3)$$

<sup>4</sup>实际目标更为细致：我们不仅要极小化目标函数  $F$ ，还希望找到能产生良好泛化模型的参数  $\mathbf{w}$ ，即总体风险较小；见第 14 章。不过，本章采用极小化  $F$  的视角。




图 10.1: 式 (10.1.2) 所定义梯度下降法的两个例子. 红点表示  $w_k$ .

所以当  $\nabla F(w_k) \neq 0$  时, 充分小的步长  $h_k$  能保证算法降低目标函数值. 实践中, 调节学习率  $h_k$  可能很微妙, 因为它必须在下列相互冲突的要求之间取得平衡:

1.  $h_k$  必须足够小, 使式 (10.1.3) 中的二阶项不占主导, 并使更新式 (10.1.2) 降低目标函数值.
2.  $h_k$  又应足够大, 以保证目标函数显著下降, 从而促使算法更快收敛.

学习率过高可能越过极小值, 过低则会导致收敛缓慢. 常用策略特别包括常学习率 (对所有  $k \in \mathbb{N}_0$  取  $h_k = h$ )、学习率调度方案, 例如衰减学习率 (当  $k \rightarrow \infty$  时  $h_k \searrow 0$ ), 以及自适应方法. 在自适应方法中, 算法根据  $j \leq k$  时的  $F(w_j)$  或  $\nabla F(w_j)$  动态调整  $h_k$ ; 见后面的第 10.4 节.

### 10.1.1 结构条件与极小化子的存在性

下面先讨论分析梯度下降算法的三个关键概念, 并从直观但不严格的几何描述开始. 称连续可微目标函数  $F: \mathbb{R}^n \rightarrow \mathbb{R}$ :

1. 光滑, 若在每个  $w \in \mathbb{R}^n$  处,  $F$  都夹在两个在  $w$  处与其图像相切的二次函数之间;
2. 凸, 若在每个  $w \in \mathbb{R}^n$  处,  $F$  都位于它在  $w$  处的切线之上;
3. 强凸, 若在每个  $w \in \mathbb{R}^n$  处,  $F$  都位于它在  $w$  处的切线加上一个凸二次项之上.

这些概念示于图 10.2. 下面给出精确的数学定义.

**定义 10.1:** 设  $n \in \mathbb{N}$ 、 $L > 0$ . 若  $F \in C^1(\mathbb{R}^n)$ , 且

$$F(v) \leq F(w) + \langle \nabla F(w), v - w \rangle + \frac{L}{2} \|w - v\|^2 \quad \text{对所有 } w, v \in \mathbb{R}^n, \quad (10.1.4a)$$

$$F(v) \geq F(w) + \langle \nabla F(w), v - w \rangle - \frac{L}{2} \|w - v\|^2 \quad \text{对所有 } w, v \in \mathbb{R}^n, \quad (10.1.4b)$$

则称  $F$  是  $L$ -光滑的 ( $L$ -smooth).




图 10.2:  $L$ -光滑函数的图像在每一点都位于两个二次函数之间, 见式 (10.1.4); 凸函数的图像在每一点都位于切线之上, 见式 (10.1.9);  $\mu$ -强凸函数的图像在每一点都位于一个凸二次函数之上, 见式 (10.1.10).

按定义,  $L$ -光滑函数满足第 1 项的几何性质. 文献中也常把  $L$ -光滑性定义为梯度的 Lipschitz 连续性:

$$\|\nabla F(\mathbf{w}) - \nabla F(\mathbf{v})\| \leq L\|\mathbf{w} - \mathbf{v}\| \quad \text{对所有 } \mathbf{w}, \mathbf{v} \in \mathbb{R}^n. \quad (10.1.5)$$

下一个引理说明两者等价; 例如见文献 [50, 215].

**引理 10.2:** 设  $L > 0$ . 则  $F \in C^1(\mathbb{R}^n)$  是  $L$ -光滑的, 当且仅当式 (10.1.5) 成立.

**证明:** 这里只证明式 (10.1.4) 蕴含式 (10.1.5). 式 (10.1.5) 蕴含式 (10.1.4) 的事实留作习题 10.17.

**步骤 1.** 先设  $F \in C^2(\mathbb{R}^n)$ , 且式 (10.1.5) 不成立. 则可找到  $\mathbf{w} \neq \mathbf{v}$ , 使得

$$\begin{aligned} \|\mathbf{w} - \mathbf{v}\| \sup_{\|\mathbf{e}\|=1} \int_0^1 \mathbf{e}^\top \nabla^2 F(\mathbf{v} + t(\mathbf{w} - \mathbf{v})) \frac{\mathbf{w} - \mathbf{v}}{\|\mathbf{w} - \mathbf{v}\|} dt &= \|\nabla F(\mathbf{w}) - \nabla F(\mathbf{v})\| \\ &> L\|\mathbf{w} - \mathbf{v}\|, \end{aligned}$$

其中  $\nabla^2 F \in \mathbb{R}^{n \times n}$  表示 Hessian 矩阵. 由于 Hessian 矩阵对称, 这意味着存在  $\mathbf{u}, \mathbf{e} \in \mathbb{R}^n$ , 满足  $\|\mathbf{e}\| = 1$  且  $|\mathbf{e}^\top \nabla^2 F(\mathbf{u})\mathbf{e}| > L$ . 因而或者

$$\mathbf{e}^\top \nabla^2 F(\mathbf{u})\mathbf{e} > L \quad \text{或者} \quad -\mathbf{e}^\top \nabla^2 F(\mathbf{u})\mathbf{e} > L. \quad (10.1.6)$$

假设第一个不等式成立. 对  $h > 0$ , 由 Taylor 公式,

$$F(\mathbf{u} + h\mathbf{e}) = F(\mathbf{u}) + h \langle \nabla F(\mathbf{u}), \mathbf{e} \rangle + \int_0^h \mathbf{e}^\top \nabla^2 F(\mathbf{u} + t\mathbf{e})\mathbf{e}(h-t) dt.$$

映射  $t \mapsto \mathbf{e}^\top \nabla^2 F(\mathbf{u} + t\mathbf{e})\mathbf{e}$  的连续性和式 (10.1.6) 中的第一个不等式说明, 对充分小的  $h > 0$ ,

$$\begin{aligned} F(\mathbf{u} + h\mathbf{e}) &> F(\mathbf{u}) + h \langle \nabla F(\mathbf{u}), \mathbf{e} \rangle + L \int_0^h (h-t) dt \\ &= F(\mathbf{u}) + \langle \nabla F(\mathbf{u}), h\mathbf{e} \rangle + \frac{L}{2} \|h\mathbf{e}\|^2. \end{aligned}$$

所以式 (10.1.4a) 不成立. 式 (10.1.6) 中的第二种情形同样导致式 (10.1.4b) 不成立.

**步骤 2.** 现在令  $F \in C^1$ , 并假设式 (10.1.4) 成立. 取非负、紧支集的  $\rho \in C^\infty(\mathbb{R}^n)$ , 满足  $\int_{\mathbb{R}^n} \rho(\mathbf{x}) \, d\mathbf{x} = 1$ ; 它称为一个磨光函数 (例如见式 (8.1.3)). 对  $\varepsilon > 0$ , 令  $\rho_\varepsilon(\mathbf{x}) := \varepsilon^{-n} \rho(\mathbf{x}/\varepsilon)$ . 标准结果 (例如文献 [94, Appendix C.5]) 表明, 卷积  $F_\varepsilon := F * \rho_\varepsilon \in C^\infty(\mathbb{R}^n)$  满足

$$\lim_{\varepsilon \rightarrow 0} \nabla F_\varepsilon(\mathbf{v}) = \nabla F(\mathbf{v}) \quad \text{对所有 } \mathbf{v} \in \mathbb{R}^n. \quad (10.1.7)$$

固定  $\varepsilon > 0$ . 由式 (10.1.4), 对所有  $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ ,

$$\begin{aligned} F_\varepsilon(\mathbf{v}) &= \int_{\mathbb{R}^n} F(\mathbf{v} - \mathbf{x}) \rho_\varepsilon(\mathbf{x}) \, d\mathbf{x} \\ &\leq \int_{\mathbb{R}^n} \left[ F(\mathbf{w} - \mathbf{x}) \rho_\varepsilon(\mathbf{x}) + \langle \nabla F(\mathbf{w} - \mathbf{x}) \rho_\varepsilon(\mathbf{x}), \mathbf{v} - \mathbf{w} \rangle + \frac{L}{2} \|\mathbf{w} - \mathbf{v}\|^2 \rho_\varepsilon(\mathbf{x}) \right] d\mathbf{x} \\ &= F_\varepsilon(\mathbf{w}) + \langle \nabla F_\varepsilon(\mathbf{w}), \mathbf{v} - \mathbf{w} \rangle + \frac{L}{2} \|\mathbf{w} - \mathbf{v}\|^2, \end{aligned}$$

其中使用了  $\nabla F_\varepsilon = \nabla F * \rho_\varepsilon$ . 因而  $F_\varepsilon$  满足式 (10.1.4a); 类似可证它满足式 (10.1.4b). 由步骤 1,  $F_\varepsilon \in C^\infty$  满足式 (10.1.5). 最后, 在式 (10.1.7) 中令  $\varepsilon \rightarrow 0$ , 便知  $F$  也满足式 (10.1.5).  $\square$

**定义 10.3:** 设  $n \in \mathbb{N}$ . 若且唯若对所有  $\mathbf{w}, \mathbf{v} \in \mathbb{R}^n, \lambda \in (0, 1)$ ,

$$F(\lambda \mathbf{w} + (1 - \lambda) \mathbf{v}) \leq \lambda F(\mathbf{w}) + (1 - \lambda) F(\mathbf{v}), \quad (10.1.8)$$

则称函数  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  是凸函数 (convex function).

当  $F$  连续可微时, 这一定义等价于第 2 项的几何性质, 如下一个引理所示. 证明留作习题 10.18.

**引理 10.4:** 设  $F \in C^1(\mathbb{R}^n)$ . 则  $F$  为凸函数, 当且仅当

$$F(\mathbf{v}) \geq F(\mathbf{w}) + \langle \nabla F(\mathbf{w}), \mathbf{v} - \mathbf{w} \rangle \quad \text{对所有 } \mathbf{w}, \mathbf{v} \in \mathbb{R}^n. \quad (10.1.9)$$

所谓强凸性强化了凸性概念: 它要求式 (10.1.9) 右端另有一个正二次项, 因此按定义对应于第 3 项的几何性质.

**定义 10.5:** 设  $n \in \mathbb{N}, \mu > 0$ . 若可微函数  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  满足

$$F(\mathbf{v}) \geq F(\mathbf{w}) + \langle \nabla F(\mathbf{w}), \mathbf{v} - \mathbf{w} \rangle + \frac{\mu}{2} \|\mathbf{v} - \mathbf{w}\|^2 \quad \text{对所有 } \mathbf{w}, \mathbf{v} \in \mathbb{R}^n, \quad (10.1.10)$$

则称  $F$  是  $\mu$ -强凸的 ( $\mu$ -strongly convex).

凸函数不必有下界 (例如  $w \mapsto w$ ), 因而不必有任何 (全局) 极小化子. 即便它有下界, 也未必存在极小化子 (例如  $w \mapsto \exp(w)$ ). 不过有如下结论.

**引理 10.6:** 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$ . 若  $F$ :

1. 为凸函数, 则  $F$  的极小化子集合是凸集, 其基数为 0、1 或  $\infty$ ;
2. 为  $\mu$ -强凸函数, 则  $F$  恰有一个极小化子.



**证明：** 设  $F$  为凸函数，并假设  $\mathbf{w}_*$  和  $\mathbf{v}_*$  是  $F$  的两个极小化子. 由式 (10.1.8)，每个凸组合  $\lambda\mathbf{w}_* + (1-\lambda)\mathbf{v}_*$  ( $\lambda \in [0, 1]$ ) 也都是极小化子. 这证明了第一个断言.

现在设  $F$  为  $\mu$ -强凸函数. 式 (10.1.10) 说明  $F$  以一个凸二次函数为下界. 因此，当  $\|\mathbf{w}\| \rightarrow \infty$  时  $F(\mathbf{w}) \rightarrow \infty$ . 于是存在有界序列  $(\mathbf{w}_j)_{j \in \mathbb{N}}$ ，使得  $F(\mathbf{w}_j) \rightarrow \inf_{\mathbf{w} \in \mathbb{R}^n} F(\mathbf{w}) > -\infty$ . 进而可取一个子列，使  $k \rightarrow \infty$  时  $\mathbf{w}_{j_k} \rightarrow \mathbf{w}_*$ . 由  $F$  的连续性， $F(\mathbf{w}_*) = \inf_{\mathbf{w} \in \mathbb{R}^n} F(\mathbf{w})$ . 由于  $\mathbf{w}_*$  是极小化子且  $F$  可微， $\nabla F(\mathbf{w}_*) = 0$ . 再由式 (10.1.10)，对每个  $\mathbf{v} \neq \mathbf{w}_*$  都有  $F(\mathbf{v}) > F(\mathbf{w}_*)$ .  $\square$

### 10.1.2 梯度下降法的收敛性

如前所述，为分析收敛性，这里只关注  $\mu$ -强凸且  $L$ -光滑的目标函数；较弱假设下的进一步结果见章末文献部分. 下述建立梯度下降法线性收敛性的定理是标准结果（例如见文献 [215, 50, 173]）. 这里的证明取自文献 [100, Theorem 3.6].

回顾：若非负实数序列  $(e_k)_{k \in \mathbb{N}}$  存在常数  $C > 0$  和  $c \in [0, 1)$ ，使得

$$e_k \leq Cc^k \quad \text{对所有 } k \in \mathbb{N}_0,$$

则称它线性收敛 (linear convergence) 到 0. 常数  $c$  也称为收敛率. 在给出定理前，先注意比较式 (10.1.4a) 和式 (10.1.10) 可知必有  $L \geq \mu$ ，因而  $\kappa := L/\mu \geq 1$ . 该量称为  $F$  的条件数 (condition number)，它决定收敛率.

**定理 10.7：** 设  $n \in \mathbb{N}$ 、 $L \geq \mu > 0$ . 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  是  $L$ -光滑且  $\mu$ -强凸的. 再设对所有  $k \in \mathbb{N}_0$  有  $h_k = h \in (0, 1/L]$ ，序列  $(\mathbf{w}_k)_{k=0}^\infty \subseteq \mathbb{R}^n$  由式 (10.1.2) 定义，且  $\mathbf{w}_*$  是  $F$  的唯一极小化子.

则当  $k \rightarrow \infty$  时， $F(\mathbf{w}_k) \rightarrow F(\mathbf{w}_*)$  和  $\mathbf{w}_k \rightarrow \mathbf{w}_*$  均线性收敛. 对特定选择  $h = 1/L$ ，所有  $k \in \mathbb{N}$  都满足

$$\|\mathbf{w}_k - \mathbf{w}_*\|^2 \leq \left(1 - \frac{\mu}{L}\right)^k \|\mathbf{w}_0 - \mathbf{w}_*\|^2, \quad (10.1.11a)$$

$$F(\mathbf{w}_k) - F(\mathbf{w}_*) \leq \frac{L}{2} \left(1 - \frac{\mu}{L}\right)^k \|\mathbf{w}_0 - \mathbf{w}_*\|^2. \quad (10.1.11b)$$

**证明：** 只需证明式 (10.1.11a)，因为由式 (10.1.11a)、式 (10.1.4a) 和  $\nabla F(\mathbf{w}_*) = 0$  可直接得到式 (10.1.11b).  $k = 0$  的情形显然，故令  $k \in \mathbb{N}$ .

展开  $\mathbf{w}_k = \mathbf{w}_{k-1} - h\nabla F(\mathbf{w}_{k-1})$ ，并使用  $\mu$ -强凸性 (10.1.10)，得到

$$\begin{aligned} \|\mathbf{w}_k - \mathbf{w}_*\|^2 &= \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 - 2h \langle \nabla F(\mathbf{w}_{k-1}), \mathbf{w}_{k-1} - \mathbf{w}_* \rangle + h^2 \|\nabla F(\mathbf{w}_{k-1})\|^2 \\ &\leq (1 - \mu h) \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 - 2h(F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)) + h^2 \|\nabla F(\mathbf{w}_{k-1})\|^2. \end{aligned} \quad (10.1.12)$$

为估计最后两项之和，先用式 (10.1.4a) 得到

$$\begin{aligned} F(\mathbf{w}_k) &\leq F(\mathbf{w}_{k-1}) + \langle \nabla F(\mathbf{w}_{k-1}), -h\nabla F(\mathbf{w}_{k-1}) \rangle + \frac{L}{2} \|h\nabla F(\mathbf{w}_{k-1})\|^2 \\ &= F(\mathbf{w}_{k-1}) + \left(\frac{L}{2} - \frac{1}{h}\right) h^2 \|\nabla F(\mathbf{w}_{k-1})\|^2. \end{aligned}$$

因此, 当  $h < 2/L$  时,

$$\begin{aligned} h^2 \|\nabla F(\mathbf{w}_{k-1})\|^2 &\leq \frac{1}{1/h - L/2} (F(\mathbf{w}_{k-1}) - F(\mathbf{w}_k)) \\ &\leq \frac{1}{1/h - L/2} (F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)), \end{aligned}$$

从而

$$\begin{aligned} &-2h(F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)) + h^2 \|\nabla F(\mathbf{w}_{k-1})\|^2 \\ &\leq \left(-2h + \frac{1}{1/h - L/2}\right) (F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)). \end{aligned}$$

若  $2h \geq 1/(1/h - L/2)$ , 等价地  $h \leq 1/L$ , 则最后一项小于或等于零.

所以当  $h \leq 1/L$  时, 式 (10.1.12) 蕴含

$$\|\mathbf{w}_k - \mathbf{w}_*\|^2 \leq (1 - \mu h) \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 \leq \cdots \leq (1 - \mu h)^k \|\mathbf{w}_0 - \mathbf{w}_*\|^2.$$

证明完毕. □

**注 10.8 (凸目标函数):** 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  是凸且  $L$ -光滑的函数, 并在  $\mathbf{w}_*$  处取得极小值. 如引理 10.6 所示, 极小化子未必唯一, 所以一般不能期待  $\mathbf{w}_k \rightarrow \mathbf{w}_*$ . 不过, 目标函数值仍然收敛. 具体而言, 在这些假设下有如下结论 [215, Theorem 2.1.14, Corollary 2.1.2]: 若对所有  $k \in \mathbb{N}_0$  有  $h_k = h \in (0, 2/L)$ , 且  $(\mathbf{w}_k)_{k=0}^\infty \subseteq \mathbb{R}^n$  由式 (10.1.2) 生成, 则

$$F(\mathbf{w}_k) - F(\mathbf{w}_*) = O(k^{-1}) \quad \text{当 } k \rightarrow \infty.$$

◇

## 10.2 随机梯度下降法

下面讨论梯度下降法的一种随机变体. 这一思想最早可追溯至 Robbins 和 Monro 的工作 [260].

其做法是用记作  $\mathbf{G}_k$  的随机变量替代式 (10.1.2) 中的梯度  $\nabla F(\mathbf{w}_k)$ . 我们把  $\mathbf{G}_k$  解释为  $\nabla F(\mathbf{w}_k)$  的近似. 更准确地说, 始终假设在给定  $\mathbf{w}_k$  后,  $\mathbf{G}_k$  是  $\nabla F(\mathbf{w}_k)$  的无偏估计量, 并且在给定  $\mathbf{w}_k$  的条件下与  $\mathbf{w}_0, \dots, \mathbf{w}_{k-1}$  独立 (见附录 A.3.3), 从而

$$\mathbb{E}[\mathbf{G}_k \mid \mathbf{w}_k] = \mathbb{E}[\mathbf{G}_k \mid \mathbf{w}_k, \dots, \mathbf{w}_0] = \nabla F(\mathbf{w}_k). \quad (10.2.1)$$

选定初值  $\mathbf{w}_0 \in \mathbb{R}^n$  后, 更新规则变为

$$\mathbf{w}_{k+1} := \mathbf{w}_k - h_k \mathbf{G}_k, \quad (10.2.2)$$

其中  $h_k > 0$  仍表示步长. 与第 10.1 节不同, 这里关注依赖于  $k$  的步长  $h_k$ .

### 10.2.1 动机与衰减学习率

下一个例子说明标准情形下该算法的动机；例如见文献 [110, Chapter 8] 或文献 [209, Section 8.4].

**例 10.9** (经验风险最小化): 假设有数据样本  $S := (\mathbf{x}_j, y_j)_{j=1}^m$ , 其中  $y_j \in \mathbb{R}$  是数据点  $\mathbf{x}_j \in \mathbb{R}^d$  对应的标签. 使用平方损失时, 希望拟合一个依赖参数 (即权重和偏置)  $\mathbf{w} \in \mathbb{R}^n$  的神经网络  $\Phi(\cdot, \mathbf{w}) : \mathbb{R}^d \rightarrow \mathbb{R}$ , 使式 (1.3) 中的经验风险

$$F(\mathbf{w}) := \frac{1}{m} \sum_{j=1}^m (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j)^2$$

达到最小. 执行一步梯度下降需要计算

$$\nabla F(\mathbf{w}) = \frac{2}{m} \sum_{j=1}^m (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j) \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}), \quad (10.2.3)$$

因而要计算神经网络  $\Phi$  的  $m$  个梯度. 当  $m$  很大时 (实践中  $m$  可以达到数百万甚至更多), 这一计算可能不可行.

为降低计算成本, 用随机梯度

$$\mathbf{G} := 2(\Phi(\mathbf{x}_j, \mathbf{w}) - y_j) \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w})$$

替代完整梯度 (10.2.3), 其中  $j \sim \text{uniform}(1, \dots, m)$  是离散集合  $\{1, \dots, m\}$  上均匀分布的随机变量. 那么

$$\mathbb{E}[\mathbf{G}] = \frac{2}{m} \sum_{j=1}^m (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j) \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}) = \nabla F(\mathbf{w}),$$

即  $\mathbf{G}$  是  $\nabla F(\mathbf{w})$  的无偏估计量. 重要的是, 计算  $\mathbf{G}$  的一个实现只需对神经网络作一次梯度计算.

更一般地, 可以选取大小为  $m_b$  的小批量 (mini-batch) <sup>5</sup> (其中  $m_b \ll m$ ), 并令


$$\mathbf{G} = \frac{2}{m_b} \sum_{j \in J} (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j) \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}),$$

其中  $J$  是  $\{1, \dots, m\}$  的一个随机子集, 基数为  $m_b$ . 较大的小批量规模会减小  $\mathbf{G}$  的方差 (从而更稳健地估计真实梯度), 但会增加计算成本.


一个相关的常用变体如下. 设  $m_b k = m$ , 其中  $m_b, k, m \in \mathbb{N}$ , 即数据点数  $m$  是小批量规模  $m_b$  的  $k$  倍. 在每个轮次 (epoch) 中, 先确定一个随机分割  $\dot{\bigcup}_{i=1}^k J_i = \{1, \dots, m\}$ , 其中对每个  $i$  都有  $|J_i| = m_b$ . 随后对每个  $i = 1, \dots, k$ , 用梯度估计

$$\frac{2}{m_b} \sum_{j \in J_i} (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j) \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w})$$

更新权重. 因此, 在一个轮次中 (对应  $k$  次权重更新), 算法遍历整个数据集, 每个数据点恰使用一次.  $\diamond$




(a) SGD 使用常学习率




(b) SGD 使用衰减学习率

图 10.3: 对一个强凸二次目标函数执行 20 步梯度下降法 (GD) 和随机梯度下降法 (SGD). GD 使用常学习率; SGD 分别使用常学习率 ( $h_k = h$ ) 和衰减学习率 ( $h_k \sim 1/k$ ).



(a)  $w_k$  远离  $w_*$



(b)  $w_k$  接近  $w_*$

图 10.4: 更新向量  $-h_k \mathbf{G}_k$  (黑色) 是一个随机变量的抽样, 该随机变量的期望为  $-h_k \nabla F(\mathbf{w}_k)$  (蓝色). 为了得到收敛性, 当  $\mathbf{w}_k$  接近极小化子  $\mathbf{w}_*$  时, 更新向量的方差应当减小. 否则一般不会收敛, 见图 10.3(a).

设  $\mathbf{w}_k$  由式 (10.2.2) 生成. 利用  $L$ -光滑性 (10.1.5), 有 [42, Lemma 4.2]

$$\begin{aligned} \mathbb{E}[F(\mathbf{w}_{k+1}) \mid \mathbf{w}_k] - F(\mathbf{w}_k) &\leq \mathbb{E}[\langle \nabla F(\mathbf{w}_k), \mathbf{w}_{k+1} - \mathbf{w}_k \rangle \mid \mathbf{w}_k] + \frac{L}{2} \mathbb{E}[\|\mathbf{w}_{k+1} - \mathbf{w}_k\|^2 \mid \mathbf{w}_k] \\ &= -h_k \|\nabla F(\mathbf{w}_k)\|^2 + \frac{L}{2} \mathbb{E}[\|h_k \mathbf{G}_k\|^2 \mid \mathbf{w}_k]. \end{aligned}$$

要使目标函数在期望意义下下降, 第一项  $h_k \|\nabla F(\mathbf{w}_k)\|^2$  应当支配第二项  $\frac{L}{2} \mathbb{E}[\|h_k \mathbf{G}_k\|^2 \mid \mathbf{w}_k]$ . 当  $\mathbf{w}_k$  接近极小值时,  $\|\nabla F(\mathbf{w}_k)\| \rightarrow 0$ , 这表明  $\mathbb{E}[\|h_k \mathbf{G}_k\|^2 \mid \mathbf{w}_k]$  也应随时间减小.

这一现象示于图 10.3(a): 在一个二次目标函数上, 随机梯度下降法使用常学习率  $h_k = h$ , 并人为加入梯度噪声, 使  $\mathbb{E}[\|\mathbf{G}_k\|^2 \mid \mathbf{w}_k]$  不趋于零. 式 (10.2.2) 中的随机更新导致优化路径波动. 由于这些波动在算法接近极小值时并不减小, 迭代点不会收敛, 而是稳定在极小值的一个邻域内并围绕它振荡; 例如见文献 [100, Theorem 9.8]. 实践中, 这可能已能给出对  $\mathbf{w}_*$  足够好的近似. 不过, 要得到极限意义下的收敛, 更新向量  $-h_k \mathbf{G}_k$

<sup>5</sup>与之相对, 使用完整批量对应于标准梯度下降法.

的方差必须随时间减小. 这可以通过减小  $\mathbf{G}_k$  的方差实现, 例如使用更大的小批量 (比较例 10.9); 更常见的做法是随  $k$  增大而减小步长  $h_k$ . 图 10.3(b) 展示了  $h_k \sim 1/k$  的情形; 另见图 10.4.

### 10.2.2 随机梯度下降法的收敛性

由于式 (10.2.2) 中的  $\mathbf{w}_k$  按构造是随机变量, 收敛性陈述只能是随机的, 例如在期望意义下或以高概率成立. 下一个定理以文献 [114, Theorem 3.2] 和文献 [42, Theorem 4.7] 为基础, 关注前一种情形. 该结果在假设 (10.2.6) 下陈述; 这一假设控制随机梯度  $\mathbf{G}_k$  的二阶矩, 并保证它至多随  $\|\nabla F(\mathbf{w}_k)\|^2$  线性增长. 此外, 分析采用文献 [114] 中的如下衰减步长:

$$h_k := \min \left( \frac{\mu}{L^2 \gamma}, \frac{1}{\mu} \frac{(k+1)^2 - k^2}{(k+1)^2} \right) \quad \text{对所有 } k \in \mathbb{N}_0. \quad (10.2.4)$$

注意, 当  $k \rightarrow \infty$  时  $h_k = O(k^{-1})$ , 因为

$$\frac{(k+1)^2 - k^2}{(k+1)^2} = \frac{2k+1}{(k+1)^2} = \frac{2}{k+1} + O(k^{-2}). \quad (10.2.5)$$

这一学习率衰减将使我们能够建立一个收敛率. 不过在实践中, 可能更倾向于采用较缓慢的衰减, 或根据观测到的收敛行为降低学习率的启发式方法.

**定理 10.10:** 设  $n \in \mathbb{N}$ ,  $L, \mu, \gamma > 0$ . 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  是  $L$ -光滑且  $\mu$ -强凸的. 固定  $\mathbf{w}_0 \in \mathbb{R}^n$ , 令  $(h_k)_{k=0}^\infty$  如式 (10.2.4) 所示, 并令  $(\mathbf{G}_k)_{k=0}^\infty$ 、 $(\mathbf{w}_k)_{k=1}^\infty$  是式 (10.2.1) 与式 (10.2.2) 中的随机变量序列. 假设对某个固定的  $\gamma > 0$  和所有  $k \in \mathbb{N}_0$ ,

$$\mathbb{E}[\|\mathbf{G}_k\|^2 \mid \mathbf{w}_k] \leq \gamma(1 + \|\nabla F(\mathbf{w}_k)\|^2). \quad (10.2.6)$$

则存在常数  $C = C(\mathbf{w}_0, \gamma, \mu, L)$ , 使得对所有  $k \in \mathbb{N}$ ,

$$\begin{aligned} \mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2] &\leq \frac{C}{k}, \\ \mathbb{E}[F(\mathbf{w}_k)] - F(\mathbf{w}_*) &\leq \frac{C}{k}. \end{aligned}$$

**证明:** 利用式 (10.2.1) 和式 (10.2.6), 对  $k \geq 1$  有

$$\begin{aligned} &\mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2 \mid \mathbf{w}_{k-1}] \\ &= \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 - 2h_{k-1}\mathbb{E}[\langle \mathbf{G}_{k-1}, \mathbf{w}_{k-1} - \mathbf{w}_* \rangle \mid \mathbf{w}_{k-1}] + h_{k-1}^2\mathbb{E}[\|\mathbf{G}_{k-1}\|^2 \mid \mathbf{w}_{k-1}] \\ &\leq \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 - 2h_{k-1}\langle \nabla F(\mathbf{w}_{k-1}), \mathbf{w}_{k-1} - \mathbf{w}_* \rangle + h_{k-1}^2\gamma(1 + \|\nabla F(\mathbf{w}_{k-1})\|^2). \end{aligned}$$

由  $\mu$ -强凸性 (10.1.10),

$$\begin{aligned} &-2h_{k-1}\langle \nabla F(\mathbf{w}_{k-1}), \mathbf{w}_{k-1} - \mathbf{w}_* \rangle \\ &\leq -\mu h_{k-1}\|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 - 2h_{k-1}(F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)). \end{aligned}$$

此外,  $L$ -光滑性、 $\mu$ -强凸性和  $\nabla F(\mathbf{w}_*) = \mathbf{0}$  蕴含

$$\|\nabla F(\mathbf{w}_{k-1})\|^2 \leq L^2 \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 \leq \frac{2L^2}{\mu} (F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)).$$

合并以上估计, 得到

$$\begin{aligned} \mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2 \mid \mathbf{w}_{k-1}] &\leq (1 - \mu h_{k-1}) \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 + h_{k-1}^2 \gamma \\ &\quad + 2h_{k-1} \left( \frac{L^2 \gamma}{\mu} h_{k-1} - 1 \right) (F(\mathbf{w}_{k-1}) - F(\mathbf{w}_*)). \end{aligned}$$

再由  $h_{k-1} \leq \mu/(L^2 \gamma)$ , 有

$$\mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2 \mid \mathbf{w}_{k-1}] \leq (1 - \mu h_{k-1}) \|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2 + h_{k-1}^2 \gamma.$$

注意两边仍是随机变量. 取全期望并利用塔式性质 (tower property) (例如见文献 [162, Satz 8.1.4]), 得到

$$\mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2] \leq (1 - \mu h_{k-1}) \mathbb{E}[\|\mathbf{w}_{k-1} - \mathbf{w}_*\|^2] + h_{k-1}^2 \gamma.$$

令  $e_0 := \|\mathbf{w}_0 - \mathbf{w}_*\|^2$ , 并对  $k \geq 1$  令  $e_k := \mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2]$ . 则

$$\begin{aligned} e_k &\leq (1 - \mu h_{k-1}) e_{k-1} + h_{k-1}^2 \gamma \\ &\leq (1 - \mu h_{k-1}) ((1 - \mu h_{k-2}) e_{k-2} + h_{k-2}^2 \gamma) + h_{k-1}^2 \gamma \\ &\leq \cdots \leq e_0 \prod_{j=0}^{k-1} (1 - \mu h_j) + \gamma \sum_{j=0}^{k-1} h_j^2 \prod_{i=j+1}^{k-1} (1 - \mu h_i). \end{aligned}$$

注意存在  $k_0 \in \mathbb{N}$ , 使得由式 (10.2.4) 和式 (10.2.5),

$$h_i = \frac{1}{\mu} \frac{(i+1)^2 - i^2}{(i+1)^2} \quad \text{对所有 } i \geq k_0.$$

因此存在依赖于  $\gamma, \mu, L$  但与  $k$  无关的  $\tilde{C}$ , 使得

$$\prod_{i=j}^{k-1} (1 - \mu h_i) \leq \tilde{C} \prod_{i=j}^{k-1} \frac{i^2}{(i+1)^2} = \tilde{C} \frac{j^2}{k^2} \quad \text{对所有 } 1 \leq j \leq k,$$

并且

$$\prod_{i=0}^{k-1} (1 - \mu h_i) \leq \frac{\tilde{C}}{k^2}.$$

从而

$$\begin{aligned} \mathbb{E}[\|\mathbf{w}_k - \mathbf{w}_*\|^2] = e_k &\leq \frac{\tilde{C}}{k^2} e_0 + \tilde{C} \frac{\gamma}{\mu^2} \sum_{j=0}^{k-1} \left( \frac{(j+1)^2 - j^2}{(j+1)^2} \right)^2 \frac{(j+1)^2}{k^2} \\ &\leq \frac{\tilde{C}}{k^2} e_0 + \frac{\tilde{C} \gamma}{\mu^2} \frac{1}{k^2} \sum_{j=0}^{k-1} \underbrace{\frac{(2j+1)^2}{(j+1)^2}}_{\leq 4} \\ &\leq \frac{\tilde{C}}{k^2} e_0 + \frac{\tilde{C} \gamma}{\mu^2} \frac{4k}{k^2} \leq \frac{C}{k}, \end{aligned}$$

其中  $C = C(\mathbf{w}_0, \gamma, \mu, L)$ .

最后, 利用  $L$ -光滑性,

$$F(\mathbf{w}_k) - F(\mathbf{w}_*) \leq \langle \nabla F(\mathbf{w}_*), \mathbf{w}_k - \mathbf{w}_* \rangle + \frac{L}{2} \|\mathbf{w}_k - \mathbf{w}_*\|^2 = \frac{L}{2} \|\mathbf{w}_k - \mathbf{w}_*\|^2,$$

再取期望即可完成证明.  $\square$

式 (10.2.4) 中  $h_k$  的特定选择简化了证明中的计算, 但渐近收敛并不要求必须这样选取. 经典地说, 在与上述类似的假设下, 若正步长满足  $\sum_{k \in \mathbb{N}} h_k = \infty$  和  $\sum_{k \in \mathbb{N}} h_k^2 < \infty$ , 则可以证明 SGD 收敛; 例如见文献 [42, Section 4]、文献 [35, Chapter 4], 或最初的文献 [260].

## 10.3 加速

加速是训练神经网络的一项重要工具 [298]. Polyak 于 1964 年首次以“重球法”之名提出这一思想 [246]. 它受到重球沿损失景观谷地滚落这一动力学图景的启发. 此后, 人们又提出并分析了其他类型的加速方法, 其中最著名的是 Nesterov 加速 [216]. 本节首先针对一个简单的二次损失讨论重球法, 以给出一些直观认识. 随后转向 Nesterov 加速, 并对  $L$ -光滑且  $\mu$ -强凸的目标函数给出收敛性证明; 所得界优于梯度下降的相应结果.

### 10.3.1 重球法

我们沿用文献 [107, 247, 250] 的思路说明其动机. 考虑二维二次目标函数

$$F(\mathbf{w}) := \frac{1}{2} \mathbf{w}^\top \mathbf{D} \mathbf{w} \quad \text{其中} \quad \mathbf{D} = \begin{pmatrix} \zeta_1 & 0 \\ 0 & \zeta_2 \end{pmatrix}, \quad (10.3.1)$$

其中  $\zeta_1 \geq \zeta_2 > 0$ . 显然,  $F$  在  $\mathbf{w}_* = \mathbf{0} \in \mathbb{R}^2$  处有唯一极小化子. 从某个  $\mathbf{w}_0 \in \mathbb{R}^2$  出发, 采用常步长  $h > 0$  的梯度下降产生迭代

$$\begin{aligned} \mathbf{w}_{k+1} &= \mathbf{w}_k - h \mathbf{D} \mathbf{w}_k = \begin{pmatrix} 1 - h\zeta_1 & 0 \\ 0 & 1 - h\zeta_2 \end{pmatrix} \mathbf{w}_k \\ &= \begin{pmatrix} (1 - h\zeta_1)^{k+1} & 0 \\ 0 & (1 - h\zeta_2)^{k+1} \end{pmatrix} \mathbf{w}_0. \end{aligned}$$

该方法对任意初值  $\mathbf{w}_0$  收敛, 当且仅当

$$|1 - h\zeta_1| < 1 \quad \text{且} \quad |1 - h\zeta_2| < 1.$$

在两个坐标方向上平衡收敛速度的最优步长为

$$h_* = \operatorname{argmin}_{h>0} \max\{|1 - h\zeta_1|, |1 - h\zeta_2|\} = \frac{2}{\zeta_1 + \zeta_2}. \quad (10.3.2)$$






图 10.5: 在目标函数 (10.3.1) 上, 梯度下降 (GD) 和重球法 (HB) 的 20 步迭代, 其中  $\zeta_1 = 12 \gg 1 = \zeta_2$ , 步长  $h = \alpha = h_*$  取式 (10.3.2) 中的值, 并令  $\beta = 1/3$ . 本图据文献 [247, 图 6] 绘制.

令  $\kappa = \zeta_1/\zeta_2$ , 便得到收敛率

$$|1 - h_*\zeta_1| = |1 - h_*\zeta_2| = \frac{\zeta_1 - \zeta_2}{\zeta_1 + \zeta_2} = \frac{\kappa - 1}{\kappa + 1} \in [0, 1). \quad (10.3.3)$$

若  $\zeta_1 \gg \zeta_2$ , 这一项接近 1, 故收敛很慢. 这与我们对强凸目标函数的分析一致: 由习题 10.23,  $F$  的条件数为  $\kappa = \zeta_1/\zeta_2 \gg 1$ . 因而定理 10.7 中的上界仅缓慢收敛. 对于  $\mathbb{R}^n$  中的一般二次目标函数, 例如

$$\tilde{F}(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{A} \mathbf{w} + \mathbf{b}^\top \mathbf{w} + c, \quad (10.3.4)$$

其中  $\mathbf{A} \in \mathbb{R}^{n \times n}$  对称正定、 $\mathbf{b} \in \mathbb{R}^n$  且  $c \in \mathbb{R}$ , 也有类似结论; 见习题 10.24.

**注 10.11:** 将式 (10.3.4) 解释为某个目标函数在其极小化子附近的二阶 Taylor 近似可知: 对于极小化子处 Hessian 矩阵病态的一般目标函数, 上述效应同样会出现.  $\diamond$

图 10.5 进一步揭示了当  $\zeta_1 \gg \zeta_2$  时梯度下降在式 (10.3.1) 上表现不佳的原因. 损失景观形似峡谷 (一个方向上的导数远大于另一方向), 而在谷底之外,  $\nabla F$  主要指向峡谷对侧. 因此, 迭代点在第一坐标方向上来回振荡, 而沿第二坐标轴所对应的谷地方向进展甚微. 为处理这一问题, 重球法引入“动量”项, 可在一定程度上缓解这种效应. 其思想是不仅根据当前位置的梯度选取更新, 还要加入此前各步的信息. 初始化  $\mathbf{w}_0$ , 并例如令  $\mathbf{w}_1 = \mathbf{w}_0 - \alpha \nabla F(\mathbf{w}_0)$  后, 对  $k \in \mathbb{N}$  取

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha \nabla F(\mathbf{w}_k) + \beta(\mathbf{w}_k - \mathbf{w}_{k-1}). \quad (10.3.5)$$

这称为 Polyak 重球法 [246, 247]. 这里  $\alpha > 0$  和  $\beta \in (0, 1)$  是超参数 (也可以依赖于  $k$ ); 实践中需要仔细调节二者, 以平衡梯度项和动量项的强度. 在给定初始化下迭代展开式 (10.3.5), 可见对  $k \geq 0$ ,

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha \left( \sum_{j=0}^k \beta^j \nabla F(\mathbf{w}_{k-j}) \right). \quad (10.3.6)$$

因此， $\mathbf{w}_k$  的更新使用了全部既往梯度的指数加权移动平均。将动量参数  $\beta$  选在区间  $(0, 1)$  内，可确保先前梯度对更新的影响呈指数衰减。 $\beta$  的具体取值决定了近期梯度与较早梯度影响之间的平衡。

直观上，既往梯度的这一线性组合会平均掉图 10.5 中梯度下降所呈现的部分振荡：在既往梯度同向的方向（第二坐标轴）上，更新向量得到增强；在梯度符号交替的方向（第一坐标轴）上，更新向量则受到抑制。类似地，使用随机梯度时，它也有助于减小部分方差。

如前所述，重球法可解释为球沿损失景观谷地滚落这一动力学过程的离散化。若球具有正质量，即它是“重”的，则其动量会防止球过度来回弹跳。下一个注阐明了这一联系。

**注 10.12：** 如文献 [247, 250] 等所指出，对  $\alpha$  和  $\beta$  作适当选择，可将式 (10.3.5) 解释为二阶常微分方程

$$m\mathbf{w}''(t) = -\nabla F(\mathbf{w}(t)) - r\mathbf{w}'(t) \quad (10.3.7)$$

的离散化。该方程描述质量为  $m$  的质点在力场  $-\nabla F(\mathbf{w}(t))$  作用下的运动；项  $-\mathbf{w}'(t)$  指向当前速度的反方向，对应摩擦力，而  $r > 0$  为摩擦系数。离散化

$$m \frac{\mathbf{w}_{k+1} - 2\mathbf{w}_k + \mathbf{w}_{k-1}}{h^2} = -\nabla F(\mathbf{w}_k) - r \frac{\mathbf{w}_{k+1} - \mathbf{w}_k}{h}$$

导出

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \underbrace{\frac{h^2}{m+rh}}_{=\alpha} \nabla F(\mathbf{w}_k) + \underbrace{\frac{m}{m+rh}}_{=\beta} (\mathbf{w}_k - \mathbf{w}_{k-1}), \quad (10.3.8)$$

从而得到式 (10.3.5)；参见文献 [250]。

在式 (10.3.8) 中令  $m = 0$ ，便恢复梯度下降更新 (10.1.2)。因此，正质量  $m > 0$  对应于动量项。反过来，梯度下降更新可解释为梯度流

$$\mathbf{w}'(t) = -\nabla F(\mathbf{w}(t)) \quad (10.3.9)$$

的 Euler 离散化。注意，在式 (10.3.9) 中， $-\nabla F(\mathbf{w}(t))$  表示  $\mathbf{w}(t)$  的速度；而在式 (10.3.7) 中，除去摩擦项，它对应于加速度。◇

### 10.3.2 Nesterov 加速

Nesterov 加速梯度法 (NAG) [216, 215] 建立在重球法之上。初始化  $\mathbf{w}_0, \mathbf{v}_0 \in \mathbb{R}^n$  后，对  $k \geq 0$  将更新写成如下两步过程：

$$\mathbf{w}_{k+1} = \mathbf{v}_k - \alpha \nabla F(\mathbf{v}_k), \quad (10.3.10a)$$

$$\mathbf{v}_{k+1} = \mathbf{w}_{k+1} + \beta(\mathbf{w}_{k+1} - \mathbf{w}_k), \quad (10.3.10b)$$

其中  $\alpha > 0$  和  $\beta \in (0, 1)$  仍为超参数。将第二行代入第一行，对  $k \geq 1$  得

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha \nabla F(\mathbf{v}_k) + \beta(\mathbf{w}_k - \mathbf{w}_{k-1}).$$

与重球法 (10.3.5) 相比, 关键区别在于: 梯度并非在当前位置  $\mathbf{w}_k$  处求值, 而是在点  $\mathbf{v}_k = \mathbf{w}_k + \beta(\mathbf{w}_k - \mathbf{w}_{k-1})$  处求值; 该点可解释为下一次迭代位置的估计. 这改善了算法对于超参数设置的稳定性和稳健性; 见文献 [181, 第 4、5 节].

下面讨论 NAG 对  $L$ -光滑且  $\mu$ -强凸的目标函数  $F$  的收敛性. 为便于分析, 先将式 (10.3.10) 改写为三序列更新. 令  $\tau = \sqrt{\mu/L}$ 、 $\alpha = 1/L$  且  $\beta = (1 - \tau)/(1 + \tau)$ . 初始化  $\mathbf{w}_0, \mathbf{v}_0 \in \mathbb{R}^n$  后, 式 (10.3.10) 也可写为  $\mathbf{u}_0 = ((1 + \tau)\mathbf{v}_0 - \mathbf{w}_0)/\tau$ , 并且对  $k \geq 0$ ,

$$\mathbf{v}_k = \frac{\tau}{1 + \tau} \mathbf{u}_k + \frac{1}{1 + \tau} \mathbf{w}_k, \quad (10.3.11a)$$

$$\mathbf{w}_{k+1} = \mathbf{v}_k - \frac{1}{L} \nabla F(\mathbf{v}_k), \quad (10.3.11b)$$

$$\mathbf{u}_{k+1} = \mathbf{u}_k + \tau(\mathbf{v}_k - \mathbf{u}_k) - \frac{\tau}{\mu} \nabla F(\mathbf{v}_k). \quad (10.3.11c)$$

见习题 10.25. 下一个定理的证明遵循文献 [313, 定理 A.3.1]、文献 [325, 命题 10] 的思路; 另见文献 [324, 命题 20], 其中基于相同参考文献给出了相关结果的类似证明.

**定理 10.13:** 设  $n \in \mathbb{N}$ 、 $0 < \mu \leq L$ , 且  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  是  $L$ -光滑、 $\mu$ -强凸函数. 再设  $\mathbf{w}_0, \mathbf{v}_0 \in \mathbb{R}^n$ , 令  $\tau = \sqrt{\mu/L}$ . 设  $(\mathbf{v}_k, \mathbf{w}_{k+1}, \mathbf{u}_{k+1})_{k=0}^\infty \subseteq \mathbb{R}^n$  由式 (10.3.11a) 定义, 并设  $\mathbf{w}_*$  为  $F$  的唯一极小化子.

则对所有  $k \in \mathbb{N}_0$ , 都有

$$\|\mathbf{u}_k - \mathbf{w}_*\|^2 \leq \frac{2}{\mu} \left(1 - \sqrt{\frac{\mu}{L}}\right)^k \left(F(\mathbf{w}_0) - F(\mathbf{w}_*) + \frac{\mu}{2} \|\mathbf{u}_0 - \mathbf{w}_*\|^2\right), \quad (10.3.12a)$$

$$F(\mathbf{w}_k) - F(\mathbf{w}_*) \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^k \left(F(\mathbf{w}_0) - F(\mathbf{w}_*) + \frac{\mu}{2} \|\mathbf{u}_0 - \mathbf{w}_*\|^2\right). \quad (10.3.12b)$$

**证明:** 定义

$$e_k := (F(\mathbf{w}_k) - F(\mathbf{w}_*)) + \frac{\mu}{2} \|\mathbf{u}_k - \mathbf{w}_*\|^2. \quad (10.3.13)$$

为证明式 (10.3.12), 只需令  $c := 1 - \tau$ , 并证明对所有  $k \in \mathbb{N}_0$  均有  $e_{k+1} \leq ce_k$ .

**步骤 1.** 对式 (10.3.13) 所定义的  $e_{k+1}$  中第一项作界. 利用  $L$ -光滑性 (10.1.4a) 和式 (10.3.11b),

$$\begin{aligned} F(\mathbf{w}_{k+1}) - F(\mathbf{v}_k) &\leq \langle \nabla F(\mathbf{v}_k), \mathbf{w}_{k+1} - \mathbf{v}_k \rangle + \frac{L}{2} \|\mathbf{w}_{k+1} - \mathbf{v}_k\|^2 \\ &= -\frac{1}{2L} \|\nabla F(\mathbf{v}_k)\|^2. \end{aligned}$$

因此, 由  $c + \tau = 1$ ,

$$\begin{aligned} F(\mathbf{w}_{k+1}) - F(\mathbf{w}_*) &\leq (F(\mathbf{v}_k) - F(\mathbf{w}_*)) - \frac{1}{2L} \|\nabla F(\mathbf{v}_k)\|^2 \\ &= c(F(\mathbf{w}_k) - F(\mathbf{w}_*)) + c(F(\mathbf{v}_k) - F(\mathbf{w}_k)) \\ &\quad + \tau(F(\mathbf{v}_k) - F(\mathbf{w}_*)) - \frac{1}{2L} \|\nabla F(\mathbf{v}_k)\|^2. \end{aligned} \quad (10.3.14)$$

**步骤 2.** 对式 (10.3.13) 所定义的  $e_{k+1}$  中第二项作界. 由式 (10.3.11c),

$$\begin{aligned}
& \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{w}_*\|^2 - \frac{\mu}{2} \|\mathbf{u}_k - \mathbf{w}_*\|^2 \\
&= \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k + \mathbf{u}_k - \mathbf{w}_*\|^2 - \frac{\mu}{2} \|\mathbf{u}_k - \mathbf{w}_*\|^2 \\
&= \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 + \mu \left\langle \tau(\mathbf{v}_k - \mathbf{u}_k) - \frac{\tau}{\mu} \nabla F(\mathbf{v}_k), \mathbf{u}_k - \mathbf{w}_* \right\rangle \\
&= \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 + \tau \langle \nabla F(\mathbf{v}_k), \mathbf{w}_* - \mathbf{u}_k \rangle - \tau \mu \langle \mathbf{v}_k - \mathbf{u}_k, \mathbf{w}_* - \mathbf{u}_k \rangle. \quad (10.3.15)
\end{aligned}$$

利用  $\mu$ -强凸性 (10.1.10), 得到

$$\begin{aligned}
\tau \langle \nabla F(\mathbf{v}_k), \mathbf{w}_* - \mathbf{u}_k \rangle &= \tau \langle \nabla F(\mathbf{v}_k), \mathbf{v}_k - \mathbf{u}_k \rangle + \tau \langle \nabla F(\mathbf{v}_k), \mathbf{w}_* - \mathbf{v}_k \rangle \\
&\leq \tau \langle \nabla F(\mathbf{v}_k), \mathbf{v}_k - \mathbf{u}_k \rangle - \tau (F(\mathbf{v}_k) - F(\mathbf{w}_*)) - \frac{\tau \mu}{2} \|\mathbf{v}_k - \mathbf{w}_*\|^2.
\end{aligned}$$

此外,

$$\begin{aligned}
& -\frac{\tau \mu}{2} \|\mathbf{v}_k - \mathbf{w}_*\|^2 - \tau \mu \langle \mathbf{v}_k - \mathbf{u}_k, \mathbf{w}_* - \mathbf{u}_k \rangle \\
&= -\frac{\tau \mu}{2} \left( \|\mathbf{v}_k - \mathbf{w}_*\|^2 - 2 \langle \mathbf{v}_k - \mathbf{u}_k, \mathbf{v}_k - \mathbf{w}_* \rangle + 2 \langle \mathbf{v}_k - \mathbf{u}_k, \mathbf{v}_k - \mathbf{u}_k \rangle \right) \\
&= -\frac{\tau \mu}{2} (\|\mathbf{u}_k - \mathbf{w}_*\|^2 + \|\mathbf{v}_k - \mathbf{u}_k\|^2).
\end{aligned}$$

于是式 (10.3.15) 不超过

$$\begin{aligned}
& \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 + \tau \langle \nabla F(\mathbf{v}_k), \mathbf{v}_k - \mathbf{u}_k \rangle - \tau (F(\mathbf{v}_k) - F(\mathbf{w}_*)) \\
& \quad - \frac{\tau \mu}{2} \|\mathbf{u}_k - \mathbf{w}_*\|^2 - \frac{\tau \mu}{2} \|\mathbf{v}_k - \mathbf{u}_k\|^2.
\end{aligned}$$

由式 (10.3.11a) 有  $\tau(\mathbf{v}_k - \mathbf{u}_k) = \mathbf{w}_k - \mathbf{v}_k$ , 故结合  $c = 1 - \tau$  可得

$$\begin{aligned}
\frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{w}_*\|^2 &\leq c \frac{\mu}{2} \|\mathbf{u}_k - \mathbf{w}_*\|^2 + \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 \\
&\quad + \langle \nabla F(\mathbf{v}_k), \mathbf{w}_k - \mathbf{v}_k \rangle - \tau (F(\mathbf{v}_k) - F(\mathbf{w}_*)) - \frac{\mu}{2\tau} \|\mathbf{w}_k - \mathbf{v}_k\|^2. \quad (10.3.16)
\end{aligned}$$

**步骤 3.** 证明  $e_{k+1} \leq ce_k$ . 将式 (10.3.14) 与式 (10.3.16) 相加, 得到

$$\begin{aligned}
e_{k+1} &\leq ce_k + c(F(\mathbf{v}_k) - F(\mathbf{w}_*)) - \frac{1}{2L} \|\nabla F(\mathbf{v}_k)\|^2 + \frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 \\
&\quad + \langle \nabla F(\mathbf{v}_k), \mathbf{w}_k - \mathbf{v}_k \rangle - \frac{\mu}{2\tau} \|\mathbf{w}_k - \mathbf{v}_k\|^2.
\end{aligned}$$

利用式 (10.3.11a) 和式 (10.3.11c) 展开

$$\begin{aligned}
\frac{\mu}{2} \|\mathbf{u}_{k+1} - \mathbf{u}_k\|^2 &= \frac{\mu}{2} \left\| \mathbf{w}_k - \mathbf{v}_k - \frac{\tau}{\mu} \nabla F(\mathbf{v}_k) \right\|^2 \\
&= \frac{\mu}{2} \|\mathbf{w}_k - \mathbf{v}_k\|^2 - \tau \langle \nabla F(\mathbf{v}_k), \mathbf{w}_k - \mathbf{v}_k \rangle + \frac{\tau^2}{2\mu} \|\nabla F(\mathbf{v}_k)\|^2,
\end{aligned}$$

从而

$$e_{k+1} \leq ce_k + \left( \frac{\tau^2}{2\mu} - \frac{1}{2L} \right) \|\nabla F(\mathbf{v}_k)\|^2 - \frac{\mu}{2\tau} \|\mathbf{w}_k - \mathbf{v}_k\|^2 \\ + c \left( F(\mathbf{v}_k) - F(\mathbf{w}_k) + \langle \nabla F(\mathbf{v}_k), \mathbf{w}_k - \mathbf{v}_k \rangle \right) + \frac{\mu}{2} \|\mathbf{w}_k - \mathbf{v}_k\|^2.$$

利用  $\mu$ -强凸性 (10.1.10) 以及  $\mu \leq L$ , 可将最后一行估计为

$$c \left( f(\mathbf{v}_k) - f(\mathbf{w}_k) + \langle \nabla F(\mathbf{v}_k), \mathbf{w}_k - \mathbf{v}_k \rangle \right) + \frac{\mu}{2} \|\mathbf{v}_k - \mathbf{w}_k\|^2 \\ \leq -(1 - \tau) \frac{\mu}{2} \|\mathbf{v}_k - \mathbf{w}_k\|^2 + \frac{\mu}{2} \|\mathbf{v}_k - \mathbf{w}_k\|^2 \leq \frac{\tau L}{2} \|\mathbf{v}_k - \mathbf{w}_k\|^2.$$

综上,

$$e_{k+1} \leq ce_k + \left( \frac{\tau^2}{2\mu} - \frac{1}{2L} \right) \|\nabla F(\mathbf{v}_k)\|^2 + \left( \frac{\tau L}{2} - \frac{\mu}{2\tau} \right) \|\mathbf{w}_k - \mathbf{v}_k\|^2 = ce_k,$$

其中括号内的两项均因  $\tau = \sqrt{\mu/L}$  而消失. 证明完毕.  $\square$

比较梯度下降的结果 (10.1.11) 与 NAG 的结果 (10.3.12) 可知, 对于强凸目标函数, 改进体现在收敛率上: 梯度下降的收敛率为  $1 - \kappa^{-16}$ , 而 NAG 的收敛率为  $1 - \kappa^{-1/2}$ , 其中  $\kappa = L/\mu$ . NAG 的收敛率仅依赖于条件数  $\kappa$  的平方根. 因而, 对于  $\kappa$  很大的病态问题, 我们预期加速方法会有好得多的表现.

## 10.4 自适应学习率与逐坐标学习率

近年来, 人们提出并研究了大量用于训练神经网络的一阶 (梯度下降) 方法. 其中许多方法采用了以下部分或全部关键策略: 随机梯度、加速和自适应步长. 第 10.2 节和第 10.3 节已经介绍了随机梯度与加速的概念, 本节将简要讨论自适应学习率. 具体而言, 我们依照原始论文 [87, 337, 309, 161], 尤其是综述 [110, 第 8.5 节]、文献 [263]、文献 [102, 第 11 章] 和文献 [209, 第 8.4 节], 说明 AdaGrad、RMSProp 和 Adam 背后的主要思想. 上述参考文献给出了直观的综合介绍, 也包含本书略去的若干其他变体. 此外, 实践中还会使用批量归一化、梯度裁剪、正则化与 dropout、提前停止、特定的权重初始化等各种其他技术和启发式方法. 本书不讨论这些内容, 例如可参见文献 [41, 110, 102, 249, 209].

### 10.4.1 逐坐标缩放

在第 10.3.1 节中, 我们已经看到普通梯度下降为何会对病态目标函数效率低下. 在高维优化问题中, 例如训练神经网络时, 这一问题可能尤其突出, 因为某些参数对网络输出的影响远大于其他参数. 因而, 单一学习率可能不是最优的: 参数空间中梯度较小的方向更新过慢, 而在梯度较大的方向上, 算法又可能越过目标位置. 为处理这一问题, 一种方案是用反映参数空间几何结构的矩阵乘以梯度, 从而对梯度作预条件处理; 例如

<sup>6</sup>关于更精确的收敛率  $(1 - \kappa^{-1})^2 / (1 + \kappa^{-1})^2 = 1 - 4\kappa^{-1} + O(\kappa^{-2})$ , 另见文献 [215, 定理 2.1.15].

见文献 [7, 221]. 一种更简单且计算高效的替代方案是分别缩放梯度的每个分量, 这对应于对角预条件矩阵. 由此, 不同坐标可采用不同的学习率, 并有助于缓解病态性, 但仅当病态方向与坐标轴对齐时才有效.

关键问题是如何设置这些学习率. 文献 [87] 首次提出的主要思想, 是按照既往梯度大小的倒数成比例地缩放各个分量. 用文献 [87] 作者的话说: “我们的程序会为频繁出现的特征赋予很低的学习率, 而为不常出现的特征赋予很高的学习率.”

初始化  $\mathbf{u}_0 = \mathbf{0} \in \mathbb{R}^n$ 、 $\mathbf{s}_0 = \mathbf{0} \in \mathbb{R}^n$  和  $\mathbf{w}_0 \in \mathbb{R}^n$  后, 下面讨论的所有方法都是

$$\mathbf{u}_{k+1} = \beta_1 \mathbf{u}_k + \beta_2 \nabla F(\mathbf{w}_k), \quad (10.4.1a)$$

$$\mathbf{s}_{k+1} = \gamma_1 \mathbf{s}_k + \gamma_2 \nabla F(\mathbf{w}_k) \odot \nabla F(\mathbf{w}_k), \quad (10.4.1b)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha_k \mathbf{u}_{k+1} \oslash \sqrt{\mathbf{s}_{k+1} + \varepsilon} \quad (10.4.1c)$$

的特例, 其中  $k \in \mathbb{N}_0$ , 而  $\alpha_k$ 、 $\beta_1$ 、 $\beta_2$ 、 $\gamma_1$ 、 $\gamma_2$  和  $\varepsilon$  是某些超参数. 这里  $\odot$  和  $\oslash$  分别表示逐分量 (Hadamard) 乘法和除法, 而  $\sqrt{\mathbf{s}_{k+1} + \varepsilon}$  理解为向量  $(\sqrt{s_{k+1,i} + \varepsilon})_i$ . 式 (10.4.1a) 定义一个更新向量; 若  $\beta_1 \in (0, 1)$ , 它对应于重球动量. 若  $\beta_1 = 0$ , 则  $\mathbf{u}_{k+1}$  只是当前梯度的倍数. 式 (10.4.1b) 定义缩放向量  $\mathbf{s}_{k+1}$ , 用来为式 (10.4.1c) 中更新向量的各坐标设置学习率. 常数  $\varepsilon > 0$  取得很小但为正, 以避免式 (10.4.1c) 中除以零. 这类方法常与小批量结合使用; 见第 10.2 节. 为简单起见, 这里用完整梯度表述它们.

**例 10.14:** 考虑目标函数  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  及其重缩放版本

$$F_\zeta(\mathbf{w}) := F(\mathbf{w} \odot \zeta) \quad \text{其梯度为} \quad \nabla F_\zeta(\mathbf{w}) = \zeta \odot \nabla F(\mathbf{w} \odot \zeta),$$

其中  $\zeta \in (0, \infty)^n$ . 将梯度下降 (10.1.2) 应用于  $F_\zeta$ , 得到更新

$$\mathbf{w}_{k+1} = \mathbf{w}_k - h_k \zeta \odot \nabla F(\mathbf{w} \odot \zeta).$$

另一方面, 令  $\varepsilon = 0$ , 式 (10.4.1) 给出的更新为

$$\begin{aligned} \mathbf{w}_{k+1} = \mathbf{w}_k - \alpha_k & \left( \beta_2 \sum_{j=0}^k \beta_1^j \nabla F(\mathbf{w}_{k-j} \odot \zeta) \right) \\ & \oslash \sqrt{\gamma_2 \sum_{j=0}^k \gamma_1^j \nabla F(\mathbf{w}_{k-j} \odot \zeta) \odot \nabla F(\mathbf{w}_{k-j} \odot \zeta)}. \end{aligned}$$

注意, 外部缩放因子  $\zeta$  因除法而消失; 在此意义下, 该更新对目标函数的逐分量重缩放具有不变性.  $\diamond$

## 10.4.2 算法

AdaGrad [87] 是 Adaptive Gradient Algorithm (自适应梯度算法) 的缩写, 它对应于式 (10.4.1) 中

$$\beta_1 = 0, \quad \gamma_1 = \beta_2 = \gamma_2 = 1, \quad \alpha_k = \alpha \quad \text{对所有 } k \in \mathbb{N}_0.$$

这留下超参数  $\varepsilon > 0$  和  $\alpha > 0$ . 这里  $\alpha > 0$  可理解为“全局”学习率. TensorFlow [1] 中的默认值为  $\alpha = 0.001$  和  $\varepsilon = 10^{-7}$ . 此时 AdaGrad 更新为

$$\begin{aligned}\mathbf{s}_{k+1} &= \mathbf{s}_k + \nabla F(\mathbf{w}_k) \odot \nabla F(\mathbf{w}_k), \\ \mathbf{w}_{k+1} &= \mathbf{w}_k - \alpha \nabla F(\mathbf{w}_k) \oslash \sqrt{\mathbf{s}_{k+1} + \varepsilon}.\end{aligned}$$

由

$$\mathbf{s}_{k+1} = \sum_{j=0}^k \nabla F(\mathbf{w}_j) \odot \nabla F(\mathbf{w}_j) \quad (10.4.2)$$

可知, 该算法在更新中按全部既往梯度平方和加  $\varepsilon$  后的平方根之倒数, 逐分量缩放梯度  $\nabla F(\mathbf{w}_k)$ . 注意, 如果分量  $i$  的既往梯度较小, 则缩放因子  $(s_{k+1,i} + \varepsilon)^{-1/2}$  较大, 反之亦然.

RMSProp 是 Root Mean Squared Propagation (均方根传播) 的缩写, 由 Tieleman 和 Hinton [309] 提出. 它对应于式 (10.4.1) 中

$$\beta_1 = 0, \quad \beta_2 = 1, \quad \gamma_2 = 1 - \gamma_1 \in (0, 1), \quad \alpha_k = \alpha \quad \text{对所有 } k \in \mathbb{N}_0,$$

因而实际留下超参数  $\varepsilon > 0$ ,  $\gamma_1 \in (0, 1)$  和  $\alpha > 0$ . TensorFlow [1] 中的默认值为  $\varepsilon = 10^{-7}$ ,  $\alpha = 0.001$  和  $\gamma_1 = 0.9$ . 因此该算法由下式给出:

$$\mathbf{s}_{k+1} = \gamma_1 \mathbf{s}_k + (1 - \gamma_1) \nabla F(\mathbf{w}_k) \odot \nabla F(\mathbf{w}_k), \quad (10.4.3a)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha \nabla F(\mathbf{w}_k) \oslash \sqrt{\mathbf{s}_{k+1} + \varepsilon}. \quad (10.4.3b)$$

缩放向量可表示为

$$\mathbf{s}_{k+1} = (1 - \gamma_1) \sum_{j=0}^k \gamma_1^j \nabla F(\mathbf{w}_{k-j}) \odot \nabla F(\mathbf{w}_{k-j}),$$

它对应于既往梯度平方的指数加权移动平均. 在 AdaGrad (10.4.2) 中, 既往梯度会无限累积; 与此不同, RMSProp 对更早的梯度作指数降权, 从而赋予近期更新更大的权重. 这可防止 AdaGrad 中有时出现的学习率衰减过快和收敛缓慢; 例如见文献 [326, 102]. 出于同样的原因, Adadelta [337] 的作者提出使用既往  $m$  个梯度平方的移动窗口平均作为缩放向量, 其中  $m \in \mathbb{N}$  固定. 关于 Adadelta 的更多细节, 见文献 [337, 263]. 标准 RMSProp 算法不含动量, 但文献 [309] 已提及加入动量的可能性; 另见文献 [298].

Adam [161] 是 Adaptive Moment Estimation (自适应矩估计) 的缩写, 它对应于式 (10.4.1) 中

$$\beta_2 = 1 - \beta_1 \in (0, 1), \quad \gamma_2 = 1 - \gamma_1 \in (0, 1), \quad \alpha_k = \alpha \frac{\sqrt{1 - \gamma_1^{k+1}}}{1 - \beta_1^{k+1}}$$



对所有  $k \in \mathbb{N}_0$  成立, 其中  $\alpha > 0$ . 文献 [161] 对其余参数推荐的默认值为  $\varepsilon = 10^{-8}$ 、 $\alpha = 0.001$ 、 $\beta_1 = 0.9$  和  $\gamma_1 = 0.999$ . 更新可写为

$$\mathbf{u}_{k+1} = \beta_1 \mathbf{u}_k + (1 - \beta_1) \nabla F(\mathbf{w}_k), \quad \hat{\mathbf{u}}_{k+1} = \frac{\mathbf{u}_{k+1}}{1 - \beta_1^{k+1}}, \quad (10.4.4a)$$

$$\mathbf{s}_{k+1} = \gamma_1 \mathbf{s}_k + (1 - \gamma_1) \nabla F(\mathbf{w}_k) \odot \nabla F(\mathbf{w}_k), \quad \hat{\mathbf{s}}_{k+1} = \frac{\mathbf{s}_{k+1}}{1 - \gamma_1^{k+1}}, \quad (10.4.4b)$$

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \alpha \hat{\mathbf{u}}_{k+1} \oslash \sqrt{\hat{\mathbf{s}}_{k+1} + \varepsilon}. \quad (10.4.4c)$$

与 RMSProp 相比, Adam 引入了两项修改. 第一, 由于  $\beta_1 > 0$ ,

$$\mathbf{u}_{k+1} = (1 - \beta_1) \sum_{j=0}^k \beta_1^j \nabla F(\mathbf{w}_{k-j}),$$

它对应于重球动量 (比较式 (10.3.6)). 第二, 为抵消由  $\mathbf{u}_0 = \mathbf{0}$  和  $\mathbf{s}_0 = \mathbf{0}$  引起的初始化偏差, Adam 采用偏差修正

$$\hat{\mathbf{u}}_k = \frac{\mathbf{u}_k}{1 - \beta_1^k}, \quad \hat{\mathbf{s}}_k = \frac{\mathbf{s}_k}{1 - \gamma_1^k}.$$

需要注意, 存在一些特定设置和凸优化问题, 使得 Adam (以及 RMSProp 和 Adadelta) 未必收敛到极小化子; 见文献 [259]. 文献 [259] 的作者提出了称为 AMS-Grad 的修改, 可避免这一问题. 尽管如此, Adam 仍是训练神经网络时非常流行的算法. 还要注意, 在随机优化情形下, 这类算法的收敛性证明通常仍要求“全局”学习率随  $k$  下降, 例如在式 (10.4.3b) 和式 (10.4.4c) 中取  $\alpha = O(k^{-1/2})$ .

## 10.5 反向传播

本节讨论如何将基于梯度的方法用于训练前馈神经网络.

设  $\Phi \in \mathcal{N}_{d_0}^{d_{L+1}}(\sigma; L, n)$  (见定义 3.7), 并假设激活函数满足  $\sigma \in C^1(\mathbb{R})$ . 与前面一样, 将神经网络参数记为

$$\mathbf{w} = ((\mathbf{W}^{(0)}, \mathbf{b}^{(0)}), \dots, (\mathbf{W}^{(L)}, \mathbf{b}^{(L)})), \quad (10.5.1)$$

其中权重矩阵  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ , 偏置向量  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$ . 此外, 固定一个可微损失函数  $\mathcal{L}: \mathbb{R}^{d_{L+1}} \times \mathbb{R}^{d_{L+1}} \rightarrow \mathbb{R}$ , 例如  $\mathcal{L}(\mathbf{y}, \tilde{\mathbf{y}}) = \|\mathbf{y} - \tilde{\mathbf{y}}\|^2/2$ , 并假设给定数据  $(\mathbf{x}_j, \mathbf{y}_j)_{j=1}^m \subseteq \mathbb{R}^{d_0} \times \mathbb{R}^{d_{L+1}}$ . 目标是以神经网络参数  $\mathbf{w}$  为变量, 极小化如下经验风险:

$$F(\mathbf{w}) := \frac{1}{m} \sum_{j=1}^m \mathcal{L}(\Phi(\mathbf{x}_j, \mathbf{w}), \mathbf{y}_j). \quad (10.5.2)$$

应用梯度步 (10.1.2) 更新参数, 需要计算

$$\nabla F(\mathbf{w}) = \frac{1}{m} \sum_{j=1}^m \nabla_{\mathbf{w}} \mathcal{L}(\Phi(\mathbf{x}_j, \mathbf{w}), \mathbf{y}_j).$$

对于随机方法, 如例 10.9 所述, 我们只计算数据集的一个 (随机) 子批量上的平均. 无论哪种情形, 都需要一种算法来确定  $\nabla_w \mathcal{L}(\Phi(\mathbf{x}, \mathbf{w}), \mathbf{y})$ , 即对所有  $\ell = 0, \dots, L$  确定梯度

$$\nabla_{\mathbf{b}^{(\ell)}} \mathcal{L}(\Phi(\mathbf{x}, \mathbf{w}), \mathbf{y}) \in \mathbb{R}^{d_{\ell+1}}, \quad \nabla_{\mathbf{W}^{(\ell)}} \mathcal{L}(\Phi(\mathbf{x}, \mathbf{w}), \mathbf{y}) \in \mathbb{R}^{d_{\ell+1} \times d_{\ell}}. \quad (10.5.3)$$

反向传播算法 [266] 提供了一种高效的计算方法.

### 10.5.1 基本思想

由于神经网络各层具有复合结构, 式 (10.5.2) 中的目标函数是映射的反复复合. 因而, 计算其导数需要反复应用链式法则. 直接实现会产生冗余计算, 效率很低. 存储并复用某些中间值可以显著降低复杂度. 本节先在简化的一元情形中说明这一点.

设  $f_{\ell}: \mathbb{R} \rightarrow \mathbb{R}$  对  $\ell = 1, \dots, L+1$  均可微. 我们希望计算

$$f_{L+1} \circ \dots \circ f_1$$

的导数. 对  $w \in \mathbb{R}$ , 记

$$\bar{f}^{(1)} := f_1(w), \quad \bar{f}^{(\ell)} := f_{\ell}(\bar{f}^{(\ell-1)}) \quad \text{对 } \ell = 2, \dots, L+1,$$

于是  $\bar{f}^{(L+1)} = f_{L+1} \circ \dots \circ f_1(w)$ . 由链式法则, 对任意  $w \in \mathbb{R}$ ,

$$(f_{L+1} \circ \dots \circ f_1)'(w) = f_1'(w) \prod_{\ell=2}^{L+1} f_{\ell}'(\underbrace{f_{\ell-1} \circ \dots \circ f_1(w)}_{=\bar{f}^{(\ell-1)}}) = \frac{\partial \bar{f}^{(L+1)}}{\partial w}.$$

若把  $f_{\ell}$  和  $f_{\ell}'$  的每次求值都视为一次运算, 则该公式的朴素实现需要  $O(L^2)$  次运算. 若先迭代计算并存储  $\ell = 1, \dots, L$  的值  $\bar{f}^{(\ell)}$ , 则计算量降为  $O(L)$ .

对于神经网络, 情况稍微复杂, 因为网络的每一层对应于一个既依赖前一层输出又依赖本层参数的函数. 我们仍在简化情形下考察这一点, 并假设  $f_1: \mathbb{R} \rightarrow \mathbb{R}$  以及  $f_{\ell}: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$  对  $\ell = 2, \dots, L+1$  均可微. 令

$$\bar{f}^{(1)} := f_1(w^{(0)}), \quad \bar{f}^{(\ell)} := f_{\ell}(w^{(\ell-1)}, \bar{f}^{(\ell-1)}) \quad \text{对 } \ell = 2, \dots, L+1.$$

我们的目标是计算  $L+1$  个偏导数

$$\frac{\partial \bar{f}^{(L+1)}}{\partial w^{(0)}}, \dots, \frac{\partial \bar{f}^{(L+1)}}{\partial w^{(L)}}. \quad (10.5.4)$$

这里  $w^{(\ell)} \in \mathbb{R}$  可解释为第  $\ell$  层的参数. 反复应用链式法则, 对  $\ell = 0, \dots, L$  得到

$$\frac{\partial \bar{f}^{(L+1)}}{\partial w^{(\ell)}} = \frac{\partial \bar{f}^{(\ell+1)}}{\partial w^{(\ell)}} \underbrace{\prod_{k=\ell+1}^L \frac{\partial \bar{f}^{(k+1)}}{\partial \bar{f}^{(k)}}}_{=: \alpha^{(\ell+1)}},$$

其中使用了如下事实：仅当  $k > \ell$  时， $\bar{f}^{(k)}$  才依赖于  $w^{(\ell)}$ . 注意

$$\alpha^{(\ell)} = \frac{\partial \bar{f}^{(L+1)}}{\partial \bar{f}^{(\ell)}} = \alpha^{(\ell+1)} \frac{\partial \bar{f}^{(\ell+1)}}{\partial \bar{f}^{(\ell)}} \quad \text{对所有 } \ell = 1, \dots, L+1.$$

因此，只需按顺序迭代计算

$$\bar{f}^{(1)}, \dots, \bar{f}^{(L+1)} \quad \text{以及} \quad \left( \alpha^{(L+1)}, \frac{\bar{f}^{(L+1)}}{\partial w^{(L)}} \right), \dots, \left( \alpha^{(1)}, \frac{\bar{f}^{(L+1)}}{\partial w^{(0)}} \right), \quad (10.5.5)$$

便可用  $O(L)$  次运算高效计算式 (10.5.4) 中的全部导数.  $\bar{f}^{(1)}, \dots, \bar{f}^{(L+1)}$  的计算称为前向传播，因为信息逐层通过复合的各层. 式 (10.5.5) 中第二部分的计算称为反向传播，其中从最外层函数/层开始构造梯度信息.

### 10.5.2 前馈神经网络

现在回到式 (10.5.1)–(10.5.2) 的设定，并应用第 10.5.1 节中的思想计算梯度 (10.5.3). 固定输入  $\mathbf{x} \in \mathbb{R}^{d_0}$ ，并引入记号

$$\bar{\mathbf{x}}^{(1)} := \mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}, \quad (10.5.6a)$$

$$\bar{\mathbf{x}}^{(\ell+1)} := \mathbf{W}^{(\ell)} \sigma(\bar{\mathbf{x}}^{(\ell)}) + \mathbf{b}^{(\ell)} \quad \text{对 } \ell = 1, \dots, L. \quad (10.5.6b)$$

与以往一样， $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  对向量的作用理解为逐分量作用. 采用定义 2.1 的记号，对  $\ell = 1, \dots, L$  有  $\mathbf{x}^{(\ell)} = \sigma(\bar{\mathbf{x}}^{(\ell)}) \in \mathbb{R}^{d_\ell}$ ，而  $\bar{\mathbf{x}}^{(L+1)} = \mathbf{x}^{(L+1)} = \Phi(\mathbf{x}, \mathbf{w}) \in \mathbb{R}^{d_{L+1}}$  是神经网络的输出. 因此， $\ell = 1, \dots, L$  时的  $\bar{\mathbf{x}}^{(\ell)}$  有时也称为预激活值.

下面再固定  $\mathbf{y} \in \mathbb{R}^{d_{L+1}}$ ，并记

$$\mathcal{L} := \mathcal{L}(\Phi(\mathbf{x}, \mathbf{w}), \mathbf{y}) = \mathcal{L}(\bar{\mathbf{x}}^{(L+1)}, \mathbf{y}).$$

注意，仅当  $k > \ell$  时， $\bar{\mathbf{x}}^{(k)}$  才依赖于  $(\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})$ . 对每个  $\ell$ ， $\bar{\mathbf{x}}^{(\ell+1)}$  都是  $\bar{\mathbf{x}}^{(\ell)}$  的函数，故反复应用链式法则得到

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(\ell)}} = \underbrace{\frac{\partial \mathcal{L}}{\partial \bar{\mathbf{x}}^{(L+1)}}}_{\in \mathbb{R}^{1 \times d_{L+1}}} \underbrace{\frac{\partial \bar{\mathbf{x}}^{(L+1)}}{\partial \bar{\mathbf{x}}^{(L)}}}_{\in \mathbb{R}^{d_{L+1} \times d_L}} \cdots \underbrace{\frac{\partial \bar{\mathbf{x}}^{(\ell+2)}}{\partial \bar{\mathbf{x}}^{(\ell+1)}}}_{\in \mathbb{R}^{d_{\ell+2} \times d_{\ell+1}}} \underbrace{\frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial W_{ij}^{(\ell)}}}_{\in \mathbb{R}^{d_{\ell+1} \times 1}}. \quad (10.5.7)$$

对于  $\partial \mathcal{L} / \partial b_j^{(\ell)}$  有类似计算. 为避免不必要的计算，沿用第 10.5.1 节中的思想，引入

$$\boldsymbol{\alpha}^{(\ell)} := \nabla_{\bar{\mathbf{x}}^{(\ell)}} \mathcal{L} \in \mathbb{R}^{d_\ell} \quad \text{对所有 } \ell = 1, \dots, L+1, \quad (10.5.8)$$

并注意到

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(\ell)}} = (\boldsymbol{\alpha}^{(\ell+1)})^\top \frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial W_{ij}^{(\ell)}}.$$

下面形式化说明， $\boldsymbol{\alpha}^{(\ell)}$  可以按  $\ell = L+1, \dots, 1$  递归计算. 这解释了“反向传播”这一名称. 与前面一样， $\odot$  表示逐分量乘积.

**引理 10.15:** 有

$$\boldsymbol{\alpha}^{(L+1)} = \nabla_{\bar{\mathbf{x}}^{(L+1)}} \mathcal{L}(\bar{\mathbf{x}}^{(L+1)}, \mathbf{y}) \quad (10.5.9)$$

以及

$$\boldsymbol{\alpha}^{(\ell)} = \sigma'(\bar{\mathbf{x}}^{(\ell)}) \odot (\mathbf{W}^{(\ell)})^\top \boldsymbol{\alpha}^{(\ell+1)} \quad \text{对所有 } \ell = L, \dots, 1. \quad (10.5.10)$$

**证明:** 式 (10.5.9) 由定义成立. 对  $\ell \in \{1, \dots, L\}$ , 由链式法则,

$$\boldsymbol{\alpha}^{(\ell)} = \frac{\partial \mathcal{L}}{\partial \bar{\mathbf{x}}^{(\ell)}} = \underbrace{\left( \frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial \bar{\mathbf{x}}^{(\ell)}} \right)^\top}_{\in \mathbb{R}^{d_\ell \times d_{\ell+1}}} \underbrace{\frac{\partial \mathcal{L}}{\partial \bar{\mathbf{x}}^{(\ell+1)}}}_{\in \mathbb{R}^{d_{\ell+1} \times 1}} = \left( \frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial \bar{\mathbf{x}}^{(\ell)}} \right)^\top \boldsymbol{\alpha}^{(\ell+1)}.$$

由式 (10.5.6b), 对  $i \in \{1, \dots, d_{\ell+1}\}$ 、 $j \in \{1, \dots, d_\ell\}$ ,

$$\left( \frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial \bar{\mathbf{x}}^{(\ell)}} \right)_{ij} = \frac{\partial \bar{x}_i^{(\ell+1)}}{\partial \bar{x}_j^{(\ell)}} = W_{ij}^{(\ell)} \sigma'(\bar{x}_j^{(\ell)}).$$

因此结论成立. □

综合以上结果, 便得到式 (10.5.3) 的显式公式.

**命题 10.16:** 有

$$\nabla_{\mathbf{b}^{(\ell)}} \mathcal{L} = \boldsymbol{\alpha}^{(\ell+1)} \in \mathbb{R}^{d_{\ell+1}} \quad \text{对 } \ell = 0, \dots, L,$$

以及

$$\nabla_{\mathbf{W}^{(0)}} \mathcal{L} = \boldsymbol{\alpha}^{(1)} \mathbf{x}^\top \in \mathbb{R}^{d_1 \times d_0},$$

并且

$$\nabla_{\mathbf{W}^{(\ell)}} \mathcal{L} = \boldsymbol{\alpha}^{(\ell+1)} \sigma(\bar{\mathbf{x}}^{(\ell)})^\top \in \mathbb{R}^{d_{\ell+1} \times d_\ell} \quad \text{对 } \ell = 1, \dots, L.$$

**证明:** 由式 (10.5.6a), 对  $i, k \in \{1, \dots, d_1\}$  和  $j \in \{1, \dots, d_0\}$ ,

$$\frac{\partial \bar{x}_k^{(1)}}{\partial b_i^{(0)}} = \delta_{ki}, \quad \frac{\partial \bar{x}_k^{(1)}}{\partial W_{ij}^{(0)}} = \delta_{ki} x_j,$$

而由式 (10.5.6b), 对  $\ell \in \{1, \dots, L\}$ 、 $i, k \in \{1, \dots, d_{\ell+1}\}$  和  $j \in \{1, \dots, d_\ell\}$ ,

$$\frac{\partial \bar{x}_k^{(\ell+1)}}{\partial b_i^{(\ell)}} = \delta_{ki}, \quad \frac{\partial \bar{x}_k^{(\ell+1)}}{\partial W_{ij}^{(\ell)}} = \delta_{ki} \sigma(\bar{x}_j^{(\ell)}).$$

因此, 令  $\mathbf{e}_i = (\delta_{ki})_{k=1}^{d_{\ell+1}}$ , 有

$$\frac{\partial \mathcal{L}}{\partial b_i^{(\ell)}} = \left( \frac{\partial \bar{\mathbf{x}}^{(\ell+1)}}{\partial b_i^{(\ell)}} \right)^\top \frac{\partial \mathcal{L}}{\partial \bar{\mathbf{x}}^{(\ell+1)}} = \mathbf{e}_i^\top \boldsymbol{\alpha}^{(\ell+1)} = \alpha_i^{(\ell+1)} \quad \text{对 } \ell \in \{0, \dots, L\},$$

并且类似地,

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(0)}} = \left( \frac{\partial \bar{\mathbf{x}}^{(1)}}{\partial W_{ij}^{(0)}} \right)^\top \boldsymbol{\alpha}^{(1)} = x_j \mathbf{e}_i^\top \boldsymbol{\alpha}^{(1)} = x_j \alpha_i^{(1)},$$

以及

$$\frac{\partial \mathcal{L}}{\partial W_{ij}^{(\ell)}} = \sigma(\bar{x}_j^{(\ell)}) \alpha_i^{(\ell+1)} \quad \text{对 } \ell \in \{1, \dots, L\}.$$

证明完毕. □

引理 10.15 和命题 10.16 导出了算法 1. 算法首先以前向传播计算  $\ell = 1, \dots, L+1$  时的  $\bar{\mathbf{x}}^{(\ell)}$ , 随后以反向传播确定  $\ell = L+1, \dots, 1$  时的  $\boldsymbol{\alpha}^{(\ell)}$ , 以及  $\mathcal{L}$  关于神经网络参数的梯度. 这说明了如何使用前面各节的基于梯度的优化器训练神经网络.

这里需要作两点重要说明. 第一, 与神经网络对应的目标函数作为神经网络权重和偏置的函数通常不是凸的. 因而, 前面各节的分析一般不能直接应用. 不过, 它仍可能为 (局部) 极小化子附近的局部收敛行为提供一些认识. 第二, 我们假设激活函数连续可微, 而 ReLU 并不满足这一条件. 利用次梯度概念, 可以在一定程度上将基于梯度的算法及其分析推广到不可微目标函数; 见习题 10.20–10.22.

---

#### 算法 1 反向传播

---

**输入:** 网络输入  $\mathbf{x}$ 、目标输出  $\mathbf{y}$ 、神经网络参数  $((\mathbf{W}^{(0)}, \mathbf{b}^{(0)}), \dots, (\mathbf{W}^{(L)}, \mathbf{b}^{(L)}))$

**输出:** 损失函数  $\mathcal{L}$  关于神经网络参数的梯度

##### 前向传播

$$\bar{\mathbf{x}}^{(1)} \leftarrow \mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}$$

**循环**  $\ell = 1, \dots, L$  **执行**

$$\bar{\mathbf{x}}^{(\ell+1)} \leftarrow \mathbf{W}^{(\ell)} \sigma(\bar{\mathbf{x}}^{(\ell)}) + \mathbf{b}^{(\ell)}$$

**结束 循环**

##### 反向传播

$$\boldsymbol{\alpha}^{(L+1)} \leftarrow \nabla_{\bar{\mathbf{x}}^{(L+1)}} \mathcal{L}(\bar{\mathbf{x}}^{(L+1)}, \mathbf{y})$$

**循环**  $\ell = L, \dots, 1$  **执行**

$$\nabla_{\mathbf{b}^{(\ell)}} \mathcal{L} \leftarrow \boldsymbol{\alpha}^{(\ell+1)}$$

$$\nabla_{\mathbf{W}^{(\ell)}} \mathcal{L} \leftarrow \boldsymbol{\alpha}^{(\ell+1)} \sigma(\bar{\mathbf{x}}^{(\ell)})^\top$$

$$\boldsymbol{\alpha}^{(\ell)} \leftarrow \sigma'(\bar{\mathbf{x}}^{(\ell)}) \odot (\mathbf{W}^{(\ell)})^\top \boldsymbol{\alpha}^{(\ell+1)}$$

**结束 循环**

$$\nabla_{\mathbf{b}^{(0)}} \mathcal{L} \leftarrow \boldsymbol{\alpha}^{(1)}$$

$$\nabla_{\mathbf{W}^{(0)}} \mathcal{L} \leftarrow \boldsymbol{\alpha}^{(1)} \mathbf{x}^\top$$


---

## 文献与延伸阅读

第 10.1 节给出的光滑强凸函数梯度下降收敛性证明沿用文献 [100]；该文汇集了多种（随机）梯度下降方法的简单证明及详细参考文献。关于梯度下降和凸优化的标准教科书，例如见文献 [34, 214, 215, 44, 28, 221, 173, 50, 22]。这些参考文献也包含在弱于本章假设的条件下所得的收敛性证明。关于例如假设 Polyak–Łojasiewicz 不等式（该不等式不要求凸性）的收敛性结果，见文献 [156]。

第 10.2 节讨论的随机梯度下降法（SGD）最早可追溯到 Robbins 和 Monro [260]。本章针对强凸目标函数给出的证明基于文献 [114, 42]，尤其采用了文献 [114] 中的步长；另见文献 [208, 256, 213, 286]。关于 SGD 在泛化性质方面可能带来的益处，例如见文献 [327, 122, 339, 159, 291]。

第 10.3 节中的重球法源自 Polyak [246]。为说明该算法的动机，我们采用文献 [107, 247, 250] 的思路，并推荐参见文献 [295, 224]。Nesterov 加速 [216] 的分析沿用文献 [313, 325] 中的论证，文献 [324] 也给出了类似证明。

对于第 10.4 节的自适应学习率，我们依照综述 [110, 第 8.5 节]、文献 [263] 和文献 [102, 第 11 章]，以及分别引入 AdaGrad [87]、Adadelata [337]、RMSProp [309] 和 Adam [161] 的原始工作。关于 RMSProp 和 Adam 的分析，我们推荐文献 [259]；该文给出了不收敛的例子，并提出称为 AMSGrad 的算法修改及其收敛性分析；另见近期论文 [302]。文献 [77] 还给出了 AdaGrad 和 Adam（若干变体）的收敛性证明。

第 10.5 节讨论的反向传播算法由 Rumelhart、Hinton 和 Williams [266] 推广普及。关于其历史发展的更多细节，参见文献 [273, 第 5.5 节]；关于该算法的进一步讨论与细节，例如见文献 [125, 36, 219, 31]。

近期文献 [308]、文献 [148] 和文献 [14] 也在深度学习语境中给出了与本章类似的梯度下降算法讨论：文献 [308, 第 7 章] 在不同光滑性和凸性假设下给出了（随机）梯度下降与梯度流的易读收敛性证明；文献 [148, 第三部分] 对深度学习中的优化技术作了更广泛的概述，但部分分析限于二次目标函数；文献 [14, 第 5、15 章] 尤其增加了方差缩减这一主题。与文献 [42] 一样，我们对梯度下降、随机梯度下降和 Nesterov 加速的分析仅关注强凸目标函数。关于机器学习中优化算法更详细的一般性论述与分析，以及本章略去的多种方法，我们也推荐该文。文献 [209, 210] 给出了略去证明的综合概述。Python 实现的细节例如见文献 [102]，实现建议与技巧另见文献 [177, 41]。

## 习题

10.17. 设  $L > 0$ , 且  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  连续可微. 证明式 (10.1.5) 蕴含式 (10.1.4).

10.18. 设  $F \in C^1(\mathbb{R}^n)$ . 证明:  $F$  是定义 10.3 意义下的凸函数, 当且仅当

$$F(\mathbf{w}) + \langle \nabla F(\mathbf{w}), \mathbf{v} - \mathbf{w} \rangle \leq F(\mathbf{v}) \quad \text{对所有 } \mathbf{w}, \mathbf{v} \in \mathbb{R}^n.$$

**定义 10.19:** 对于凸函数  $F: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $\mathbf{g} \in \mathbb{R}^n$  称为  $F$  在  $\mathbf{v}$  处的**次梯度** (或次微分), 当且仅当

$$F(\mathbf{w}) \geq F(\mathbf{v}) + \langle \mathbf{g}, \mathbf{w} - \mathbf{v} \rangle \quad \text{对所有 } \mathbf{w} \in \mathbb{R}^n. \quad (10.5.11)$$

$F$  在  $\mathbf{v}$  处的所有次梯度组成的集合记为  $\partial F(\mathbf{v})$ .

对于凸函数  $F$ , 次梯度总是存在, 即  $\partial F(\mathbf{v})$  必非空; 例如见文献 [50, 第 1.2 节]. 次梯度推广了凸函数梯度的概念, 因为对于任意连续可微凸函数  $F$ , 取  $\mathbf{g} = \nabla F(\mathbf{v})$  即满足式 (10.5.11). 下面三道关于次梯度的习题基于讲义 [45]. 关于次梯度下降的更多细节, 另见文献 [287, 50, 173].

10.20. 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  为凸函数, 且  $\text{Lip}(F) \leq L$ . 证明: 任意  $\mathbf{g} \in \partial F(\mathbf{v})$  均满足  $\|\mathbf{g}\| \leq L$ .

10.21. 设  $F: \mathbb{R}^n \rightarrow \mathbb{R}$  为凸函数,  $\text{Lip}(F) \leq L$ , 并假设  $\mathbf{w}_*$  是  $F$  的极小化子. 固定  $\mathbf{w}_0 \in \mathbb{R}^n$ , 并对  $k \in \mathbb{N}_0$  定义**次梯度下降更新**

$$\mathbf{w}_{k+1} := \mathbf{w}_k - h_k \mathbf{g}_k,$$

其中  $\mathbf{g}_k$  是  $\partial F(\mathbf{w}_k)$  中任意固定的元素. 证明

$$\min_{i \leq k} F(\mathbf{w}_i) - F(\mathbf{w}_*) \leq \frac{\|\mathbf{w}_0 - \mathbf{w}_*\|^2 + L^2 \sum_{i=1}^k h_i^2}{2 \sum_{i=1}^k h_i}.$$

提示: 先递归展开  $\|\mathbf{w}_k - \mathbf{w}_*\|^2 = \dots$ , 再应用次梯度的性质.

10.22. 考虑习题 10.21 的设定. 确定步长  $h_1, \dots, h_k$  (它们可以依赖于  $k$ , 即写成  $h_{k,1}, \dots, h_{k,k}$ ), 使得  $\delta > 0$ ,

$$\min_{i \leq k} F(\mathbf{w}_i) - F(\mathbf{w}_*) = O(k^{-1/2}) \quad \text{当 } k \rightarrow \infty.$$

10.23. 设  $\mathbf{A} \in \mathbb{R}^{n \times n}$  对称半正定、 $\mathbf{b} \in \mathbb{R}^n$  且  $c \in \mathbb{R}$ . 将  $\mathbf{A}$  的特征值记为  $\zeta_1 \geq \dots \geq \zeta_n \geq 0$ . 证明目标函数

$$F(\mathbf{w}) := \frac{1}{2} \mathbf{w}^\top \mathbf{A} \mathbf{w} + \mathbf{b}^\top \mathbf{w} + c \quad (10.5.12)$$

是凸函数且为  $\zeta_1$ -光滑的. 此外, 若  $\zeta_n > 0$ , 则  $F$  是  $\zeta_n$ -强凸的. 证明这些值在如下意义下是最优的: 若  $L < \zeta_1$  或  $\mu > \zeta_n$ , 则  $F$  分别不是  $L$ -光滑或  $\mu$ -强凸的.

提示:  $L$ -光滑性与  $\mu$ -强凸性在平移和加常数下不变. 也就是说, 对每个  $\alpha \in \mathbb{R}$  和  $\beta \in \mathbb{R}^n$ ,  $\tilde{F}(\mathbf{w}) := \alpha + F(\mathbf{w} + \beta)$  是  $L$ -光滑或  $\mu$ -强凸的, 当且仅当  $F$  如此. 因而只需考虑  $\mathbf{w}^\top \mathbf{A} \mathbf{w} / 2$ .



**10.24.** 设  $F$  如习题 10.23 所示. 证明: 梯度下降对任意初值  $\mathbf{w}_0 \in \mathbb{R}^n$  收敛, 当且仅当

$$\max_{j=1,\dots,n} |1 - h\zeta_j| < 1.$$

证明

$$\operatorname{argmin}_{h>0} \max_{j=1,\dots,n} |1 - h\zeta_j| = \frac{2}{\zeta_1 + \zeta_n},$$

并推出: 若  $F$  是病态的, 即  $\zeta_1/\zeta_n \gg 1$ , 则收敛很慢.

提示: 首先假设式 (10.5.12) 中  $\mathbf{b} = \mathbf{0} \in \mathbb{R}^n$  且  $c = 0 \in \mathbb{R}$ , 并使用奇异值分解  $\mathbf{A} = \mathbf{U}^\top \operatorname{diag}(\zeta_1, \dots, \zeta_n) \mathbf{U}$ .

**10.25.** 证明: 当  $\tau = \sqrt{\mu/L}$ 、 $\alpha = 1/L$ 、 $\beta = (1 - \tau)/(1 + \tau)$ , 且初始化为  $\mathbf{u}_0 = ((1 + \tau)\mathbf{w}_0 - \mathbf{s}_0)/\tau$  时, 式 (10.3.10) 可等价写成式 (10.3.11).

# 宽神经网络与神经切线核

本章研究大宽度（浅层）神经网络的训练动力学. 全章设给定数据对

$$(\mathbf{x}_i, y_i) \in \mathbb{R}^d \times \mathbb{R} \quad i \in \{1, \dots, m\}, \quad (11.0.1a)$$

其中各  $\mathbf{x}_i$  互异. 我们希望训练一个依赖于输入  $\mathbf{x} \in \mathbb{R}^d$  和参数  $\mathbf{w} \in \mathbb{R}^n$  的模型（例如神经网络） $\Phi(\mathbf{x}, \mathbf{w})$ . 为此，我们或者极小化无岭（ridgeless）（无正则化）目标函数

$$F(\mathbf{w}) := \sum_{i=1}^m (\Phi(\mathbf{x}_i, \mathbf{w}) - y_i)^2, \quad (11.0.1b)$$

或者对某个正则化参数  $\lambda \geq 0$  极小化岭正则化（ridge regularization）目标函数

$$F_\lambda(\mathbf{w}) := F(\mathbf{w}) + \lambda \|\mathbf{w}\|^2. \quad (11.0.1c)$$

因此，形容词“有岭”和“无岭”分别表示正则化项  $\|\mathbf{w}\|^2$  存在和不存在.

在无岭情形，目标函数是样本  $S = (\mathbf{x}_i, y_i)_{i=1}^m$  和平方损失下式 (1.3) 中经验风险  $\hat{\mathcal{R}}_S(\Phi)$  的一个倍数. 正则化是机器学习中改善模型泛化能力与稳定性的常用工具，例如见文献 [168]. 本章旨在洞察训练过程中参数向量  $\mathbf{w}_k$  演化时  $\Phi(\mathbf{x}, \mathbf{w}_k)$  的动力学. 此外，我们还希望理解正则化的影响，以及当  $k$  很大时已训练模型  $\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_k)$  的行为. 我们将从所谓核方法的视角来完成这些工作. 在训练算法方面，本章只关注采用常步长的梯度下降法.

若  $\Phi(\mathbf{x}, \mathbf{w})$  关于参数  $\mathbf{w}$  线性，则目标函数 (11.0.1c) 是凸的. 根据上一章所得结果（参见注 10.8），梯度下降法此时能找到一个全局极小化子. 对典型的神经网络架构， $\mathbf{w} \mapsto \Phi(\mathbf{x}, \mathbf{w})$  并非线性的，因而这一说法一般不成立. 近期结果表明，随着网络宽度增加，神经网络的行为倾向于关于  $\mathbf{w}$  线性化 [147]. 这使我们可以把线性情形中的一些技术和结论迁移到神经网络训练中.

本章首先在第 11.1 和 11.2 节回顾描述关于  $\mathbf{w}$  线性模型的（核）最小二乘方法. 随后的各节沿文献 [179] 考察神经网络为何在无限宽极限下呈现类线性行为. 第 11.3 节引入所谓切线核. 第 11.4 节给出抽象结果，表明在适当假设下训练模型时会收敛到一个全局极小化子. 第 11.5 节在此分析基础上讨论与切线核的核回归之间的联系. 第 11.6 节随后详述这些结果对宽神经网络的意义. Telgarsky 此前也在文献 [308, Chapter 8] 中基于文献 [60]，针对梯度流（而非梯度下降法）给出了类似论述.

## 11.1 线性最小二乘回归

线性最小二乘回归可以说是最简单的机器学习算法之一，例如见文献 [78, 37, 124, 108]. 给定数据 (11.0.1a)，我们通过极小化式 (11.0.1) 中的  $F$  或  $F_\lambda$ ，拟合线性函数

$\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}) := \mathbf{x}^\top \mathbf{w}$ . 令

$$\mathbf{A} = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{pmatrix} \in \mathbb{R}^{m \times d} \quad \text{且} \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} \in \mathbb{R}^m, \quad (11.1.1)$$

则有

$$F(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|^2, \quad F_\lambda(\mathbf{w}) = F(\mathbf{w}) + \lambda\|\mathbf{w}\|^2. \quad (11.1.2)$$

$\mathbf{x}_1, \dots, \mathbf{x}_m$  称为训练点 (training point) (或设计点). 在第 11.1 节余下部分, 把它们的张成空间记作

$$\tilde{H} := \text{span}\{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subseteq \mathbb{R}^d. \quad (11.1.3)$$

这是由  $\mathbf{A}$  的各行张成的子空间.

**注 11.1:** 更一般地, 拟设  $\Phi(\mathbf{x}, (\mathbf{w}, b)) := \mathbf{w}^\top \mathbf{x} + b$  对应于

$$\Phi(\mathbf{x}, (\mathbf{w}, b)) = (1, \mathbf{x}^\top) \begin{pmatrix} b \\ \mathbf{w} \end{pmatrix}.$$

因此, 额外允许偏置也可作类似处理. ◇

### 11.1.1 极小化子的存在性

先考虑无岭情形  $\lambda = 0$ . 模型  $\Phi(\mathbf{x}, \mathbf{w}) = \mathbf{x}^\top \mathbf{w}$  关于  $\mathbf{x}$  和  $\mathbf{w}$  都是线性的. 特别地, 由习题 10.23,  $\mathbf{w} \mapsto F(\mathbf{w})$  是凸函数. 若  $\mathbf{A}$  可逆, 则  $F$  有唯一极小化子  $\mathbf{w}_* = \mathbf{A}^{-1}\mathbf{y}$ . 若  $\text{rank}(\mathbf{A}) = d$ , 则由习题 10.23,  $F$  是强凸的, 并且仍存在唯一极小化子. 然而, 若  $\text{rank}(\mathbf{A}) < d$ , 则  $\ker(\mathbf{A}) \neq \{\mathbf{0}\}$ , 且  $F$  有无穷多个极小化子. 为保证唯一性, 我们考虑最小范数解 (minimum norm solution)

$$\mathbf{w}_* := \operatorname{argmin}_{\mathbf{w} \in M} \|\mathbf{w}\|, \quad M := \{\mathbf{w} \in \mathbb{R}^d \mid F(\mathbf{w}) \leq F(\mathbf{v}) \ \forall \mathbf{v} \in \mathbb{R}^d\}. \quad (11.1.4)$$

标准结果表明,  $\mathbf{w}_*$  是良定义的, 并且属于式 (11.1.3) 所定义的训练点张成空间  $\tilde{H}$ , 例如见文献 [37, 78, 108]. 一种证明方法使用伪逆 (见定理 B.2); 这里给出另一种论证, 它可以直接推广到后面第 11.2 节讨论的无限维情形.

**定理 11.2:** 式 (11.1.4) 中存在唯一的最小范数解  $\mathbf{w}_* \in \mathbb{R}^d$ . 它属于子空间  $\tilde{H}$ , 并且是  $F$  在  $\tilde{H}$  中的唯一极小化子, 即

$$\mathbf{w}_* = \operatorname{argmin}_{\tilde{\mathbf{w}} \in \tilde{H}} F(\tilde{\mathbf{w}}). \quad (11.1.5)$$

**证明:** 先证明式 (11.1.4) 中  $\mathbf{w}_* \in \mathbb{R}^d$  的存在性与唯一性. 令

$$C := \text{span}\{\mathbf{A}\mathbf{w} \mid \mathbf{w} \in \mathbb{R}^d\} \subseteq \mathbb{R}^m.$$

则  $C$  是有限维空间, 因而闭且凸. 所以  $\mathbf{y}_* = \operatorname{argmin}_{\tilde{\mathbf{y}} \in C} \|\tilde{\mathbf{y}} - \mathbf{y}\|$  存在且唯一 (这是 Hilbert 空间的一个基本性质, 见定理 B.17). 特别地,  $F$  的极小化子集合  $M = \{\mathbf{w} \in \mathbb{R}^d \mid \mathbf{A}\mathbf{w} = \mathbf{y}_*\} \subseteq \mathbb{R}^d$  非空. 显然,  $M \subseteq \mathbb{R}^d$  闭且凸. 与前面相同,  $\mathbf{w}_* = \operatorname{argmin}_{\mathbf{w} \in M} \|\mathbf{w}\|$  存在且唯一.

还需证明式 (11.1.5). 把  $\mathbf{w}_*$  分解为  $\mathbf{w}_* = \tilde{\mathbf{w}} + \hat{\mathbf{w}}$ , 其中  $\tilde{\mathbf{w}} \in \tilde{H}$  且  $\hat{\mathbf{w}} \in \tilde{H}^\perp$  (见定义 B.15). 由  $\mathbf{A}$  的定义,  $\mathbf{A}\mathbf{w}_* = \mathbf{A}\tilde{\mathbf{w}}$  且  $F(\mathbf{w}_*) = F(\tilde{\mathbf{w}})$ . 此外,  $\|\mathbf{w}_*\|^2 = \|\tilde{\mathbf{w}}\|^2 + \|\hat{\mathbf{w}}\|^2$ . 由于  $\mathbf{w}_*$  是最小范数解, 故  $\mathbf{w}_* = \tilde{\mathbf{w}} \in \tilde{H}$ .

最后证明  $\mathbf{w}_*$  是  $F$  在  $\tilde{H}$  中的唯一极小化子. 假设  $F$  在  $\tilde{H}$  中还有一个不同于  $\mathbf{w}_*$  的极小化子  $\mathbf{v}$ . 则  $\mathbf{0} \neq \mathbf{w}_* - \mathbf{v} \in \tilde{H}$ . 因而  $\mathbf{A}(\mathbf{w}_* - \mathbf{v}) \neq \mathbf{0}$ , 以及  $\mathbf{y}_* = \mathbf{A}\mathbf{w}_* \neq \mathbf{A}\mathbf{v}$ , 这与  $\mathbf{v}$  极小化  $F$  矛盾.  $\square$

接下来在式 (11.1.2) 中令  $\lambda > 0$ . 此时, 极小化  $F_\lambda$  称为岭回归 (ridge regression), 或称 Tikhonov 正则化最小二乘 [311, 134, 92, 124]. 下一个定理表明,  $F_\lambda$  存在唯一极小化子, 并且它与最小范数解紧密相关, 例如见文献 [92, Theorem 5.2].

**定理 11.3:** 设  $\lambda > 0$ . 对式 (11.1.2) 中的  $F_\lambda$ , 存在唯一极小化子

$$\mathbf{w}_{*,\lambda} := \operatorname{argmin}_{\mathbf{w} \in \mathbb{R}^d} F_\lambda(\mathbf{w}).$$

并且  $\mathbf{w}_{*,\lambda} \in \tilde{H}$ , 以及

$$\lim_{\lambda \rightarrow 0} \mathbf{w}_{*,\lambda} = \mathbf{w}_*. \quad (11.1.6)$$

**证明:** 由习题 11.33,  $\mathbf{w} \mapsto F_\lambda(\mathbf{w})$  在  $\mathbb{R}^d$  上强凸, 因而在子空间  $\tilde{H} \subseteq \mathbb{R}^d$  上也强凸. 所以  $F_\lambda$  在  $\tilde{H}$  中存在唯一极小化子, 将其记为  $\mathbf{w}_{*,\lambda} \in \tilde{H}$ . 为证明  $F_\lambda$  在  $\mathbb{R}^d$  中没有其他极小化子, 固定  $\mathbf{w} \in \mathbb{R}^d \setminus \tilde{H}$ , 并把它分解为  $\mathbf{w} = \tilde{\mathbf{w}} + \hat{\mathbf{w}}$ , 其中  $\tilde{\mathbf{w}} \in \tilde{H}$  且  $\mathbf{0} \neq \hat{\mathbf{w}} \in \tilde{H}^\perp$ . 则

$$F(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|^2 = \|\mathbf{A}\tilde{\mathbf{w}} - \mathbf{y}\|^2 = F(\tilde{\mathbf{w}})$$

且

$$\|\mathbf{w}\|^2 = \|\tilde{\mathbf{w}}\|^2 + \|\hat{\mathbf{w}}\|^2 > \|\tilde{\mathbf{w}}\|^2.$$

故  $F_\lambda(\mathbf{w}) > F_\lambda(\tilde{\mathbf{w}}) \geq F_\lambda(\mathbf{w}_{*,\lambda})$ .

还需证明式 (11.1.6). 有

$$\begin{aligned} F_\lambda(\mathbf{w}) &= (\mathbf{A}\mathbf{w} - \mathbf{y})^\top (\mathbf{A}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{w}^\top \mathbf{w} \\ &= \mathbf{w}^\top (\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I}_d) \mathbf{w} - 2\mathbf{w}^\top \mathbf{A}^\top \mathbf{y}, \end{aligned}$$

其中  $\mathbf{I}_d \in \mathbb{R}^{d \times d}$  是单位矩阵. 极小化子在  $\nabla F_\lambda(\mathbf{w}) = \mathbf{0}$  处取得, 这给出

$$\mathbf{w}_{*,\lambda} = (\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I}_d)^{-1} \mathbf{A}^\top \mathbf{y}.$$

设  $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$  是  $\mathbf{A}$  的奇异值分解, 其中  $\mathbf{\Sigma} \in \mathbb{R}^{m \times d}$  包含非零奇异值  $s_1 \geq \cdots \geq s_r > 0$ , 而  $\mathbf{U} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{V} \in \mathbb{R}^{d \times d}$  均为正交矩阵. 则

$$\begin{aligned} \mathbf{w}_{*,\lambda} &= (\mathbf{V}(\mathbf{\Sigma}^\top \mathbf{\Sigma} + \lambda \mathbf{I}_d)\mathbf{V}^\top)^{-1} \mathbf{V} \mathbf{\Sigma}^\top \mathbf{U}^\top \mathbf{y} \\ &= \mathbf{V} \underbrace{\begin{pmatrix} \frac{s_1}{s_1^2 + \lambda} & & & 0 \\ & \ddots & & \\ & & \frac{s_r}{s_r^2 + \lambda} & \\ 0 & & & 0 \end{pmatrix}}_{\in \mathbb{R}^{d \times m}} \mathbf{U}^\top \mathbf{y}, \end{aligned}$$

其中  $\mathbf{0}$  表示大小适当的零块. 当  $\lambda \rightarrow 0$  时, 它收敛到  $\mathbf{A}^\dagger \mathbf{y}$ , 其中  $\mathbf{A}^\dagger$  表示  $\mathbf{A}$  的伪逆, 见式 (B.1.3). 由定理 B.2,  $\mathbf{A}^\dagger \mathbf{y} = \mathbf{w}_*$ .  $\square$

### 11.1.2 梯度下降法

考虑用梯度下降法极小化式 (11.1.2) 中的目标函数  $F_\lambda$ . 从  $\mathbf{w}_0 \in \mathbb{R}^d$  出发, 采用常步长  $h > 0$  的迭代更新为

$$\mathbf{w}_{k+1} = \mathbf{w}_k - 2h\mathbf{A}^\top(\mathbf{A}\mathbf{w}_k - \mathbf{y}) - 2h\lambda\mathbf{w}_k \quad \text{对所有 } k \in \mathbb{N}_0. \quad (11.1.7)$$

仍先令  $\lambda = 0$ , 即  $F_\lambda = F$ . 由于  $F$  是凸二次函数, 由注 10.8, 当步长  $h > 0$  充分小时,  $k \rightarrow \infty$  时有  $F(\mathbf{w}_k) \rightarrow F(\mathbf{w}_*)$ . 那么,  $\mathbf{w}_k$  是否也收敛到最小范数解  $\mathbf{w}_* \in \tilde{H}$ ? 回忆  $\tilde{H}$  由  $\mathbf{A}^\top$  的各列张成. 因此, 若  $\mathbf{w}_0 \in \tilde{H}$ , 则由式 (11.1.7), 迭代点  $\mathbf{w}_k$  始终不会离开子空间  $\tilde{H}$ . 因为  $\tilde{H}$  中只有一个极小化子, 所以  $k \rightarrow \infty$  时  $\mathbf{w}_k \rightarrow \mathbf{w}_*$ .

这表明, 极小化  $F$  时, 梯度下降法并非找到任意最优解; 只要  $\mathbf{w}_0 \in \tilde{H}$  (例如  $\mathbf{w}_0 = \mathbf{0}$ ), 它便收敛到最小范数解. 众所周知 [27, Theorem 16], 式 (11.1.7) 这类迭代会导向最小范数解; 下一个命题给出了更精确的表述. 为陈述该命题, 以下用  $s_{\max}(\mathbf{A})$  表示  $\mathbf{A}$  的最大奇异值, 用  $s_{\min}(\mathbf{A})$  表示其最小正奇异值; 约定在  $\mathbf{A} = \mathbf{0}$  时  $s_{\min}(\mathbf{A}) := \infty$ . 完整证明留作习题 11.32.

**命题 11.4:** 设  $\lambda = 0$ , 并固定  $h \in (0, s_{\max}(\mathbf{A})^{-2})$ . 把  $\mathbf{w}_0$  写成  $\mathbf{w}_0 = \tilde{\mathbf{w}}_0 + \hat{\mathbf{w}}_0$ , 其中  $\tilde{\mathbf{w}}_0 \in \tilde{H}$  且  $\hat{\mathbf{w}}_0 \in \tilde{H}^\perp$ ; 令  $(\mathbf{w}_k)_{k \in \mathbb{N}}$  由式 (11.1.7) 定义. 则

$$\lim_{k \rightarrow \infty} \mathbf{w}_k = \mathbf{w}_* + \hat{\mathbf{w}}_0.$$

接下来考虑岭回归, 即式 (11.1.2) 和 (11.1.7) 中  $\lambda > 0$  的情形. 下一个命题中的步长条件可以放宽为  $h \in (0, (\lambda + s_{\max}(\mathbf{A})^2)^{-1})$ , 但为简单起见, 这里不作放宽.

**命题 11.5:** 设  $\lambda > 0$ , 并固定  $h \in (0, (2\lambda + 2s_{\max}(\mathbf{A})^2)^{-1})$ . 设  $\mathbf{w}_0 \in \mathbb{R}^d$ , 且  $(\mathbf{w}_k)_{k \in \mathbb{N}}$  由式 (11.1.7) 定义. 则

$$\lim_{k \rightarrow \infty} \mathbf{w}_k = \mathbf{w}_{*,\lambda},$$

并且

$$\|\mathbf{w}_* - \mathbf{w}_{*,\lambda}\| \leq \frac{\lambda}{s_{\min}(\mathbf{A})^3 + s_{\min}(\mathbf{A})\lambda} \|\mathbf{y}\| = O(\lambda) \quad \text{当 } \lambda \rightarrow 0.$$

**证明：** 由习题 10.23,  $F_\lambda$  是  $(2\lambda + 2s_{\max}(\mathbf{A})^2)$ -光滑的；由习题 11.33,  $F_\lambda$  是强凸的. 因此, 定理 10.7 蕴含梯度下降法收敛到唯一极小化子  $\mathbf{w}_{*,\lambda}$ .

为估计它与  $\mathbf{w}_*$  的距离, 设  $\mathbf{A} \neq 0$  ( $\mathbf{A} = 0$  的情形是平凡的). 用  $\mathbf{A}$  的伪逆表示  $\mathbf{w}_*$  (见附录 B.1), 可得

$$\mathbf{w}_* = \mathbf{A}^\dagger \mathbf{y} = \mathbf{V} \begin{pmatrix} \frac{1}{s_1} & & & 0 \\ & \ddots & & \\ & & \frac{1}{s_r} & \\ 0 & & & 0 \end{pmatrix} \mathbf{U}^\top \mathbf{y},$$

其中  $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$  是  $\mathbf{A}$  的奇异值分解,  $s_1 \geq \dots \geq s_r > 0$  表示  $\mathbf{A}$  的奇异值. 再利用定理 11.3 证明中所得  $\mathbf{w}_{*,\lambda}$  的显式公式, 得到

$$\|\mathbf{w}_* - \mathbf{w}_{*,\lambda}\| \leq \max_{i \leq r} \left| \frac{s_i}{s_i^2 + \lambda} - \frac{1}{s_i} \right| \|\mathbf{y}\|.$$

这就给出了所称的界. □

由命题 11.5, 若采用很小的正则化参数  $\lambda > 0$  进行岭回归, 则无论如何初始化  $\mathbf{w}_0$ , 梯度下降法都会收敛到向量  $\mathbf{w}_{*,\lambda}$ , 而它与最小范数解  $\mathbf{w}_*$  的距离为  $O(\lambda)$ .

## 11.2 特征方法与核最小二乘回归

线性模型往往过于简单, 无法捕捉  $\mathbf{x}$  与  $y$  之间的真实关系. 特征方法 (feature method) 和基于核的方法 (例如见文献 [70, 278, 124]) 通过把  $\mathbf{x} \mapsto \langle \mathbf{x}, \mathbf{w} \rangle$  替换为  $\mathbf{x} \mapsto \langle \phi(\mathbf{x}), \mathbf{w} \rangle$  来解决这一问题, 其中  $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^n$  是一个 (通常非线性的) 映射. 这在保持模型关于参数  $\mathbf{w} \in \mathbb{R}^n$  线性的同时, 引入了关于  $\mathbf{x}$  的非线性.

**例 11.6:** 设给定数据  $(x_i, y_i)_{i=1}^m \subseteq \mathbb{R} \times \mathbb{R}$ , 并对  $x \in \mathbb{R}$  定义

$$\phi(x) := (1, x, \dots, x^{n-1})^\top \in \mathbb{R}^n.$$

对  $\mathbf{w} \in \mathbb{R}^n$ , 模型  $x \mapsto \langle \phi(x), \mathbf{w} \rangle = \sum_{j=0}^{n-1} w_j x^j$  可以表示任意  $n-1$  次多项式. ◇

下面将这一想法形式化. 出于稍后会清楚的原因 (见注 11.11), 允许  $n = \infty$  是有益的. 为此, 设  $(H, \langle \cdot, \cdot \rangle_H)$  是一个 Hilbert 空间 (见附录 B.2.4), 称为特征空间 (feature space); 设  $\phi: \mathbb{R}^d \rightarrow H$  为特征映射 (feature map). 模型定义为

$$\Phi(\mathbf{x}, w) := \langle \phi(\mathbf{x}), w \rangle_H, \quad (11.2.1)$$

其中  $w \in H$ . 以下可把  $H$  理解为某个  $n \in \mathbb{N}$  下的  $\mathbb{R}^n$ , 或者理解为  $\ell^2(\mathbb{N})$  (见例 B.12); 在最后一情形,  $\phi$  的各分量称为特征 (feature). 对某个  $\lambda \geq 0$ , 目标是极小化

$$F(w) := \sum_{j=1}^m (\langle \phi(\mathbf{x}_j), w \rangle_H - y_j)^2, \quad F_\lambda(w) := F(w) + \lambda \|w\|_H^2. \quad (11.2.2)$$

与式 (11.1.3) 类似, 在第 11.2 节余下部分, 记

$$\tilde{H} := \text{span}\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)\} \subseteq H$$

为训练点处的特征向量所张成的空间.

### 11.2.1 极小化子的存在性

先考虑式 (11.2.2) 中的无岭情形  $\lambda = 0$ . 为了保证唯一性并正则化该问题, 我们再次考虑最小范数解

$$w_* := \operatorname{argmin}_{w \in M} \|w\|_H, \quad M := \{w \in H \mid F(w) \leq F(v) \ \forall v \in H\}. \quad (11.2.3)$$

**定理 11.7:** 式 (11.2.3) 中存在唯一的最小范数解  $w_* \in H$ . 它属于子空间  $\tilde{H}$ , 并且是  $F$  在  $\tilde{H}$  中的唯一极小化子, 即

$$w_* = \operatorname{argmin}_{\tilde{w} \in \tilde{H}} F(\tilde{w}). \quad (11.2.4)$$

定理 11.2 的证明写法使其可以逐字推广到定理 11.7: 只需把  $\mathbb{R}^d$  替换为  $H$ , 并把矩阵  $\mathbf{A} \in \mathbb{R}^{m \times d}$  替换为线性映射

$$\begin{aligned} A: H &\rightarrow \mathbb{R}^m, \\ w &\mapsto (\langle \phi(\mathbf{x}_i), w \rangle_H)_{i=1}^m. \end{aligned}$$

对于式 (11.2.2) 中  $\lambda > 0$  的岭回归情形, 令

$$w_{*,\lambda} := \operatorname{argmin}_{w \in H} F_\lambda(w). \quad (11.2.5)$$

与无岭情形类似, 定理 11.3 稍加修改即可推广到当前设定. 特别地, 式 (11.2.5) 中的  $w_{*,\lambda} \in H$  存在且唯一. 关键观察仍是:  $F_\lambda$  的任意极小化子都必须属于有限维子空间  $\tilde{H}$ . 事实上, 若  $w = \tilde{w} + w^\perp$ , 其中  $\tilde{w} \in \tilde{H}$ 、 $w^\perp \in \tilde{H}^\perp$ , 则正交分量  $w^\perp$  会增大正则化项  $\lambda \|w\|_H^2 = \lambda (\|\tilde{w}\|_H^2 + \|w^\perp\|_H^2)$ , 却不影响  $F(w)$ . 为  $\tilde{H}$  选取一组基后, 证明便可类似地进行. 我们把相关核验留给读者, 见习题 11.34. 由此得到如下结论.

**定理 11.8:** 设  $\lambda > 0$ . 则式 (11.2.5) 中存在唯一极小化子  $w_{*,\lambda}$ . 并且  $w_{*,\lambda} \in \tilde{H}$ , 以及

$$\lim_{\lambda \rightarrow 0} w_{*,\lambda} = w_*.$$

定理 11.7 和 11.8 这类断言表明极小化子在有限维子空间  $\tilde{H}$  中取得, 在文献中称为表示定理 (representer theorem) [160, 277].

### 11.2.2 核技巧

下面解释它与核之间的联系. 乍看之下, 在可能为无限维的 Hilbert 空间  $H$  中极小化式 (11.2.2) 似乎不可行. 然而, 我们已经看到极小化子在有限维子空间  $\tilde{H}$  中取得. 把计算约化到这个子空间称为所谓的核技巧 (kernel trick) [40]. 为同时处理  $\lambda = 0$  和  $\lambda > 0$  的情形, 以下采用记号  $w_{*,0} := w_*$ .

**定义 11.9:** 对称函数  $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$  称为一个核 (kernel), 若对任意  $\mathbf{x}_1, \dots, \mathbf{x}_k \in \mathbb{R}^d$  和  $k \in \mathbb{N}$ , 核矩阵 (kernel matrix)  $\mathbf{G} = (K(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^k \in \mathbb{R}^{k \times k}$  都是对称半正定的.

给定特征映射  $\phi: \mathbb{R}^d \rightarrow H$ , 容易验证

$$K(\mathbf{x}, \mathbf{z}) := \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_H \quad \text{对所有 } \mathbf{x}, \mathbf{z} \in \mathbb{R}^d \quad (11.2.6)$$



定义了一个核. 相应的核矩阵  $\mathbf{G} \in \mathbb{R}^{m \times m}$  为

$$G_{ij} = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_H = K(\mathbf{x}_i, \mathbf{x}_j).$$

对  $w_{*,\lambda}$  采用拟设  $\sum_{j=1}^m \alpha_j \phi(\mathbf{x}_j)$ , 便把式 (11.2.3) (当  $\lambda = 0$ ) 和式 (11.2.5) 中的优化问题化为

$$\operatorname{argmin}_{\alpha \in \mathbb{R}^m} \|\mathbf{G}\alpha - \mathbf{y}\|^2 + \lambda \alpha^\top \mathbf{G}\alpha. \quad (11.2.7)$$

这样的极小化向量  $\alpha$  未必唯一 (当  $\mathbf{G}$  不可逆时), 但任意这样的  $\alpha$  都会在  $\tilde{H}$  中给出一个极小化子. 因而由定理 11.7 和 11.8, 对任意  $\lambda \geq 0$  均有  $w_{*,\lambda} = \sum_{j=1}^m \alpha_j \phi(\mathbf{x}_j)$ . 这提示了算法 2.

---

**算法 2** 核最小二乘回归

---

**输入:** 数据  $(\mathbf{x}_i, y_i)_{i=1}^m \in \mathbb{R}^d \times \mathbb{R}$ , 核  $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ , 正则化参数  $\lambda \geq 0$ , 求值点  $\mathbf{x} \in \mathbb{R}^d$

**输出:** 点  $\mathbf{x}$  处的 (有岭或无岭) 核最小二乘估计量

计算核矩阵  $\mathbf{G} = (K(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m$

确定  $\|\mathbf{G}\alpha - \mathbf{y}\|^2 + \lambda \alpha^\top \mathbf{G}\alpha$  的一个极小化子  $\alpha \in \mathbb{R}^m$

由下式计算  $\Phi(\mathbf{x}, w_{*,\lambda})$ :

$$\Phi(\mathbf{x}, w_{*,\lambda}) = \left\langle \phi(\mathbf{x}), \sum_{j=1}^m \alpha_j \phi(\mathbf{x}_j) \right\rangle_H = \sum_{j=1}^m \alpha_j K(\mathbf{x}, \mathbf{x}_j). \quad (11.2.8)$$


---

我们把

$$\mathbf{x} \mapsto \Phi(\mathbf{x}, w_{*,\lambda}) = \langle \phi(\mathbf{x}), w_{*,\lambda} \rangle_H$$

称为 (有岭或无岭) 核最小二乘估计量 ((ridge or ridgeless) kernel least-squares estimator). 根据上述讨论, 其计算既不需要显式知道特征映射  $\phi$ , 也不需要显式知道  $w_{*,\lambda} \in H$ . 只需选择一个核  $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ , 并在有限维空间中完成全部计算即可. 这就是核技巧. 尽管算法 2 在本章余下部分不再使用, 我们仍在此给出它, 以展示更完整的图景.

**注 11.10:** 令

$$K(\mathbf{x}, \mathbf{X}) := (K(\mathbf{x}, \mathbf{x}_1), \dots, K(\mathbf{x}, \mathbf{x}_m)) \in \mathbb{R}^{1 \times m}, \quad (11.2.9a)$$

$$K(\mathbf{X}, \mathbf{X}) := (K(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m = \mathbf{G} \in \mathbb{R}^{m \times m}. \quad (11.2.9b)$$

若  $\lambda \geq 0$  且  $K(\mathbf{X}, \mathbf{X}) + \lambda \mathbf{I}_m$  可逆 (当  $\lambda > 0$  时总是如此), 则式 (11.2.7) 的一个极小化子为

$$\alpha = (K(\mathbf{X}, \mathbf{X}) + \lambda \mathbf{I}_m)^{-1} \mathbf{y}. \quad (11.2.10)$$

当  $\lambda = 0$  时, 这直接由式 (11.2.7) 得到.  $\lambda > 0$  的情形留作习题 11.37. 利用表示式 (11.2.8), 点  $\mathbf{x} \in \mathbb{R}^d$  处的核最小二乘估计量因而可写成

$$K(\mathbf{x}, \mathbf{X})(K(\mathbf{X}, \mathbf{X}) + \lambda \mathbf{I}_m)^{-1} \mathbf{y}. \quad (11.2.11)$$

◇

**注 11.11:** 若  $\Omega \subseteq \mathbb{R}^d$  紧, 且  $K : \Omega \times \Omega \rightarrow \mathbb{R}$  是连续核, 则 Mercer 定理蕴含存在 Hilbert 空间  $H$  和特征映射  $\phi : \mathbb{R}^d \rightarrow H$ , 使得

$$K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_H \quad \text{对所有 } \mathbf{x}, \mathbf{z} \in \Omega,$$

即  $K$  是相应的核. 例如见文献 [30, Sec. 3.2] 或文献 [294, Thm. 4.49].  $\diamond$

### 11.2.3 梯度下降法

实践中, 我们既可以极小化式 (11.2.2) 中的  $F_\lambda$  (在 Hilbert 空间  $H$  中), 也可以极小化式 (11.2.7) 中的目标函数 (在  $\mathbb{R}^m$  中). 这里关注前者, 因为这使我们能在后续各节中建立与神经网络训练的联系. 为了使用梯度下降法, 假设  $H = \mathbb{R}^n$  并配备 Euclidean 内积.

从  $\mathbf{w}_0 \in \mathbb{R}^n$  初始化, 采用常步长  $h > 0$  极小化  $F_\lambda$  的梯度下降更新为

$$\mathbf{w}_{k+1} = \mathbf{w}_k - 2h\mathbf{A}^\top(\mathbf{A}\mathbf{w}_k - \mathbf{y}) - 2h\lambda\mathbf{w}_k \quad \text{对所有 } k \in \mathbb{N}_0,$$

其中现在

$$\mathbf{A} = \begin{pmatrix} \phi(\mathbf{x}_1)^\top \\ \vdots \\ \phi(\mathbf{x}_m)^\top \end{pmatrix}.$$

这对应于第 11.1.2 节所讨论的情形.

令  $\lambda = 0$ . 当步长充分小时, 由命题 11.4, 对  $\mathbf{x} \in \mathbb{R}^d$  有

$$\lim_{k \rightarrow \infty} \Phi(\mathbf{x}, \mathbf{w}_k) = \langle \phi(\mathbf{x}), \mathbf{w}_* \rangle + \langle \phi(\mathbf{x}), \hat{\mathbf{w}}_0 \rangle, \quad (11.2.12)$$

其中

$$\mathbf{w}_0 = \tilde{\mathbf{w}}_0 + \hat{\mathbf{w}}_0,$$

且  $\tilde{\mathbf{w}}_0 \in \tilde{H} = \text{span}\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)\} \subseteq \mathbb{R}^n$ ,  $\hat{\mathbf{w}}_0 \in \tilde{H}^\perp$ . 因此, 当  $\lambda = 0$  时, 梯度下降法给出无岭核最小二乘估计量, 再加上依赖于初始化的附加项  $\langle \phi(\mathbf{x}), \hat{\mathbf{w}}_0 \rangle$ . 特别地, 在集合

$$\{\mathbf{x} \in \mathbb{R}^d \mid \phi(\mathbf{x}) \in \text{span}\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)\}\} \quad (11.2.13)$$

上, 式 (11.2.12) 总与无岭最小二乘估计量一致.

现在令  $\lambda > 0$ . 当步长充分小时, 由命题 11.5, 对  $\mathbf{x} \in \mathbb{R}^d$  有

$$\lim_{k \rightarrow \infty} \Phi(\mathbf{x}, \mathbf{w}_k) = \langle \phi(\mathbf{x}), \mathbf{w}_{*,\lambda} \rangle = \langle \phi(\mathbf{x}), \mathbf{w}_* \rangle + O(\lambda) \quad \text{当 } \lambda \rightarrow 0.$$

因此, 当  $\lambda > 0$  时, 无论如何初始化, 梯度下降法都确定有岭核最小二乘估计量. 此外, 对固定的  $\mathbf{x}$ , 极限模型与无岭核最小二乘估计量的距离为  $O(\lambda)$ .

### 11.3 切线核

考虑输入为  $\mathbf{x} \in \mathbb{R}^d$ 、参数为  $\mathbf{w} \in \mathbb{R}^n$  的一般模型  $\Phi(\mathbf{x}, \mathbf{w})$ . 给定数据 (11.0.1a), 目标是极小化平方损失目标函数 (11.0.1b). 本节及随后两节的分析聚焦无岭情形. 我们将在第 11.6.4 节重新讨论岭回归, 并在那里考虑神经网络采用与不采用正则化训练时的一个简单测试例.

若  $\mathbf{w} \mapsto \Phi(\mathbf{x}, \mathbf{w})$  不是线性的, 则与第 11.1 和 11.2 节不同, 目标函数 (11.0.1b) 一般并非凸函数, 第 10 章关于一阶方法的大多数结果也不能直接应用. 因此, 我们通过在初始化处关于参数线性化模型 (linearizing the model in the parameter around initialization) 来简化问题: 固定  $\mathbf{w}_0 \in \mathbb{R}^n$ , 令

$$\Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}) := \Phi(\mathbf{x}, \mathbf{w}_0) + \langle \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}_0), \mathbf{p} \rangle \quad \text{对所有 } \mathbf{p} \in \mathbb{R}^n. \quad (11.3.1)$$

这是  $\Phi$  在初始参数  $\mathbf{w}_0$  附近的一阶 Taylor 近似. 线性化模型的参数始终记为  $\mathbf{p} \in \mathbb{R}^n$ , 以区别于完整模型的参数  $\mathbf{w}$ . 引入

$$\delta_j := y_j - \Phi(\mathbf{x}_j, \mathbf{w}_0) \quad \text{对所有 } j = 1, \dots, m. \quad (11.3.2)$$

则线性化模型的平方损失目标函数为

$$F^{\text{lin}}(\mathbf{p}) := \sum_{j=1}^m (\Phi^{\text{lin}}(\mathbf{x}_j, \mathbf{p}) - y_j)^2 = \sum_{j=1}^m (\langle \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}_0), \mathbf{p} \rangle - \delta_j)^2, \quad (11.3.3)$$

其中  $\langle \cdot, \cdot \rangle$  表示  $\mathbb{R}^n$  中的 Euclidean 内积. 与式 (11.2.2) 比较可知, 极小化  $F^{\text{lin}}$  对应于采用特征映射

$$\phi(\mathbf{x}) = \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}_0) \in \mathbb{R}^n \quad (11.3.4)$$

的核最小二乘回归. 由式 (11.2.6), 相应的核为

$$\hat{K}_n(\mathbf{x}, \mathbf{z}) = \langle \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}_0), \nabla_{\mathbf{w}} \Phi(\mathbf{z}, \mathbf{w}_0) \rangle. \quad (11.3.5)$$

我们称  $\hat{K}_n$  为经验切线核 (empirical tangent kernel), 因为它来自原模型  $\Phi$  在初始化  $\mathbf{w}_0$  附近的一阶 Taylor 近似 (即切线). 注意,  $\hat{K}_n$  依赖于  $\mathbf{w}_0$  的选择.

根据第 11.2.3 节的观察, 用梯度下降法极小化  $F^{\text{lin}}$ , 若初始化为  $\mathbf{p}_0 = \mathbf{0}$ 、步长充分小且不采用正则化, 则所得序列  $(\mathbf{p}_k)_{k \in \mathbb{N}_0}$  满足

$$\lim_{k \rightarrow \infty} \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k) = \underbrace{\Phi(\mathbf{x}, \mathbf{w}_0)}_{\text{依赖于初始化的项}} + \underbrace{\langle \phi(\mathbf{x}), \mathbf{p}_* \rangle}_{\text{采用核 } \hat{K}_n \text{ 和式 (11.3.2) 右端的无岭核最小二乘估计量}}. \quad (11.3.6)$$

第一项依赖于初始化  $\mathbf{w}_0$ . 第二项也通过式 (11.3.4) 中的特征映射和式 (11.3.2) 的右端依赖于  $\mathbf{w}_0$ . 这里用到了式 (11.3.1) 中  $\Phi^{\text{lin}}$  的定义、极限 (11.2.12), 以及  $\mathbf{p}_0 = \mathbf{0}$  这一事实; 因此式 (11.2.12) 中的第二项消失.




图 11.1:  $w \mapsto \Phi(\mathbf{x}_1, w)$  及其在初始参数  $w_0$  处的线性化  $p \mapsto \Phi^{\text{lin}}(\mathbf{x}_1, p)$  的图像, 其中  $\frac{\partial}{\partial w}\Phi(\mathbf{x}_1, w_0) \neq 0$ . 若  $\Phi$  与  $\Phi^{\text{lin}}$  接近, 则存在  $w$  使得  $\Phi(\mathbf{x}_1, w) = y_1$  (左). 若二者的导数也接近, 则损失  $(\Phi(\mathbf{x}_1, w) - y_1)^2$  关于  $w$  近似凸, 梯度下降法可以找到一个全局极小化子 (右).




图 11.2: 与图 11.1 相同. 若  $\Phi$  与  $\Phi^{\text{lin}}$  不接近, 则未必存在  $w$  使得  $\Phi(\mathbf{x}_1, w) = y_1$ , 梯度下降法也未必收敛到全局极小化子.

## 11.4 全局极小化子

考虑一般模型  $\Phi: \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ 、如式 (11.0.1a) 所示的数据, 以及无岭平方损失

$$F(\mathbf{w}) = \sum_{j=1}^m (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j)^2.$$

本节讨论梯度下降法收敛到全局极小化子的充分条件.

思路如下: 若  $\mathbf{w} \mapsto \Phi(\mathbf{x}, \mathbf{w})$  是非线性的, 但在某一区域内与式 (11.3.1) 中的线性化  $\Phi^{\text{lin}}$  足够接近, 则目标函数在该区域内的行为几乎像凸函数. 若该区域足够大, 既包含初值  $\mathbf{w}_0$ , 又包含一个全局极小点, 那么我们预期梯度下降法在训练过程中始终不会离开这个 (近似凸的) 盆地, 并能找到一个全局极小化子.

为说明这一点, 考虑图 11.1 和图 11.2, 其中训练样本数取  $m = 1$ , 参数个数取  $n = 1$ . 要使上述推理成立, 在  $\mathbf{w}_0$  的某个邻域内,  $\Phi$  与  $\Phi^{\text{lin}}$  之差以及二者导数之差都必须保持较小. 该邻域应足够大以包含全局极小化子, 因此关键地依赖于两个因素: 初始误差  $\Phi(\mathbf{x}_1, w_0) - y_1$ , 以及导数  $\frac{\partial}{\partial w}\Phi(\mathbf{x}_1, w_0)$  的大小.

现在对一般的  $m$  和  $n$ , 我们把所需的  $\Phi$  假设精确表述如下.

**假设 11.12:** 设  $\Phi \in C^1(\mathbb{R}^d \times \mathbb{R}^n)$  且  $\mathbf{w}_0 \in \mathbb{R}^n$ . 存在常数  $r, R, U, L > 0$  和  $0 < \theta_{\min} \leq \theta_{\max} < \infty$ , 使得对所有  $i = 1, \dots, m$  都有  $\|\mathbf{x}_i\| \leq R$ , 并且满足:

(a) 经验切线核的核矩阵

$$(\hat{K}_n(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m = (\langle \nabla_{\mathbf{w}}\Phi(\mathbf{x}_i, \mathbf{w}_0), \nabla_{\mathbf{w}}\Phi(\mathbf{x}_j, \mathbf{w}_0) \rangle)_{i,j=1}^m \in \mathbb{R}^{m \times m} \quad (11.4.1)$$

可逆, 且其特征值属于  $[\theta_{\min}, \theta_{\max}]$ ;

(b) 对所有满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\|\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w})\| \leq U \quad \text{对所有 } \mathbf{w} \in B_r(\mathbf{w}_0), \quad (11.4.2a)$$

$$\|\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{v})\| \leq L\|\mathbf{w} - \mathbf{v}\| \quad \text{对所有 } \mathbf{w}, \mathbf{v} \in B_r(\mathbf{w}_0); \quad (11.4.2b)$$

(c)

$$L \leq \frac{\theta_{\min}^2}{8m^{3/2}U^2\sqrt{F(\mathbf{w}_0)}} \quad \text{且} \quad r = \frac{2\sqrt{m}U\sqrt{F(\mathbf{w}_0)}}{\theta_{\min}}. \quad (11.4.3)$$

下面对这些技术假设作更直观的解释. 首先, (a) 蕴含

$$(\nabla_{\mathbf{w}}\Phi(\mathbf{x}_i, \mathbf{w}_0))_{i=1}^m \in \mathbb{R}^{m \times n}$$

具有满秩  $m \leq n$  (因此参数数目  $n$  至少与训练数据数目  $m$  一样多). 在图 11.1 的语境中, 这意味着  $\frac{\partial}{\partial \mathbf{w}}\Phi(\mathbf{x}_1, \mathbf{w}_0) \neq 0$ , 因而  $\Phi^{\text{lin}}$  不是常值函数. 这保证存在  $\mathbf{p}$ , 使得对所有  $i = 1, \dots, m$  都有  $\Phi^{\text{lin}}(\mathbf{x}_i, \mathbf{p}) = y_i$ , 即线性化模型  $\Phi^{\text{lin}}$  能够插值这些数据. 其次, (b) 特别地把  $\Phi$  与其线性化  $\Phi^{\text{lin}}$  之间所需的接近性形式化. 例如, 由于  $\Phi^{\text{lin}}$  是  $\Phi$  在  $\mathbf{w}_0$  处的一阶 Taylor 近似 (参见式 (11.3.1)),

$$\begin{aligned} |\Phi(\mathbf{x}, \mathbf{w}) - \Phi^{\text{lin}}(\mathbf{x}, \mathbf{w} - \mathbf{w}_0)| &= |(\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}) - \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0))^{\top}(\mathbf{w} - \mathbf{w}_0)| \\ &\leq L\|\mathbf{w} - \mathbf{w}_0\|^2, \end{aligned}$$

其中某个  $\tilde{\mathbf{w}}$  位于  $\mathbf{w}$  与  $\mathbf{w}_0$  的凸包中. 最后, (c) 把所有常数联系起来, 保证完整模型在  $\mathbf{w}_0$  周围一个半径为  $r$ 、足够大的球内与其线性化充分接近. 特别地, 初始误差  $\sqrt{F(\mathbf{w}_0)}$  越小或  $\theta_{\min}$  越大,  $r$  可以越小; 这与我们从图 11.1 得到的直觉一致.

现在可以陈述下面的定理, 它是文献 [179, Thm. G.1] 的一个变体, 证明紧随该文给出的论证. 在第 11.6 节, 我们将看到, 对某些 (宽) 神经网络, 该定理的主要要求——假设 11.12——以高概率成立.

**定理 11.13:** 设假设 11.12 成立. 固定一个正学习率

$$h \leq \frac{1}{\theta_{\min} + \theta_{\max}}. \quad (11.4.4)$$

令  $(\mathbf{w}_k)_{k \in \mathbb{N}}$  由梯度下降法生成, 即对所有  $k \in \mathbb{N}_0$ ,

$$\mathbf{w}_{k+1} = \mathbf{w}_k - h\nabla F(\mathbf{w}_k). \quad (11.4.5)$$

则对所有  $k \in \mathbb{N}$  都有

$$\|\mathbf{w}_k - \mathbf{w}_0\| \leq r, \quad (11.4.6a)$$

$$F(\mathbf{w}_k) \leq (1 - h\theta_{\min})^{2k} F(\mathbf{w}_0). \quad (11.4.6b)$$

**证明：** 先引入一些记号. 任取  $\tilde{\mathbf{w}}^1, \dots, \tilde{\mathbf{w}}^m \in B_r(\mathbf{w}_0) \subseteq \mathbb{R}^n$ , 并令  $\tilde{\mathbf{W}} = (\tilde{\mathbf{w}}^1, \dots, \tilde{\mathbf{w}}^m)$ . 对这  $m$  个参数向量, 我们把模型在  $m$  个数据点处的预测误差记为

$$\mathbf{e}(\tilde{\mathbf{W}}) := \begin{pmatrix} \Phi(\mathbf{x}_1, \tilde{\mathbf{w}}^1) - y_1 \\ \vdots \\ \Phi(\mathbf{x}_m, \tilde{\mathbf{w}}^m) - y_m \end{pmatrix} \in \mathbb{R}^m,$$

$$\nabla \mathbf{e}(\tilde{\mathbf{W}}) := \begin{pmatrix} \nabla_{\mathbf{w}} \Phi(\mathbf{x}_1, \tilde{\mathbf{w}}^1)^\top \\ \vdots \\ \nabla_{\mathbf{w}} \Phi(\mathbf{x}_m, \tilde{\mathbf{w}}^m)^\top \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

当  $\tilde{\mathbf{w}}^1 = \dots = \tilde{\mathbf{w}}^m = \tilde{\mathbf{w}}$  时, 我们简记为  $\mathbf{e}(\tilde{\mathbf{w}})$  和  $\nabla \mathbf{e}(\tilde{\mathbf{w}})$ . 由假设 11.12(a) 中的经验切线核  $\hat{K}_n$ , 有

$$\nabla \mathbf{e}(\mathbf{w}_0) \nabla \mathbf{e}(\mathbf{w}_0)^\top = (\hat{K}_n(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m \in \mathbb{R}^{m \times m}. \quad (11.4.7)$$

由式 (11.4.2a),

$$\|\nabla \mathbf{e}(\tilde{\mathbf{W}})\|^2 \leq \|\nabla \mathbf{e}(\tilde{\mathbf{W}})\|_F^2 = \sum_{j=1}^m \|\nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \tilde{\mathbf{w}}^j)\|^2 \leq mU^2, \quad (11.4.8a)$$

类似地, 利用式 (11.4.2b),

$$\begin{aligned} \|\nabla \mathbf{e}(\tilde{\mathbf{W}}) - \nabla \mathbf{e}(\mathbf{w}_0)\|^2 &\leq \sum_{j=1}^m \|\nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \tilde{\mathbf{w}}^j) - \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}_0)\|^2 \\ &\leq L^2 \sum_{j=1}^m \|\tilde{\mathbf{w}}^j - \mathbf{w}_0\|^2 \leq mL^2 r^2. \end{aligned} \quad (11.4.8b)$$

**步骤 1.** 令  $\rho := 1 - h\theta_{\min} \in (0, 1)$ . 在证明余下部分, 我们对  $k$  作归纳, 证明

$$\sum_{j=0}^{k-1} \|\mathbf{w}_{j+1} - \mathbf{w}_j\| \leq 2h\sqrt{m}U \|\mathbf{e}(\mathbf{w}_0)\| \sum_{j=0}^{k-1} \rho^j, \quad (11.4.9a)$$

$$\|\mathbf{e}(\mathbf{w}_k)\|^2 \leq \|\mathbf{e}(\mathbf{w}_0)\|^2 \rho^{2k}, \quad (11.4.9b)$$

对所有  $k \in \mathbb{N}_0$  成立, 其中空和理解为零. 由于  $\sum_{j=0}^{\infty} \rho^j = (1-\rho)^{-1}$  且  $\|\mathbf{e}(\mathbf{w})\| = \sqrt{F(\mathbf{w})}$ , 利用式 (11.4.3) 可得

$$2h\sqrt{m}U \|\mathbf{e}(\mathbf{w}_0)\| \sum_{j=0}^{\infty} \rho^j = 2h\sqrt{m}U \sqrt{F(\mathbf{w}_0)} \frac{1}{h\theta_{\min}} = r. \quad (11.4.10)$$

因此这些不等式直接蕴含式 (11.4.6).

当  $k = 0$  时, 式 (11.4.9) 显然成立. 对于归纳步骤, 假设式 (11.4.9) 对某个  $k \in \mathbb{N}_0$  成立.

**步骤 2.** 证明式 (11.4.9a) 对  $k+1$  成立. 归纳假设 (11.4.9a) 与式 (11.4.10) 给出  $\mathbf{w}_k \in B_r(\mathbf{w}_0)$ . 其次,

$$\nabla F(\mathbf{w}_k) = \nabla(\mathbf{e}(\mathbf{w}_k)^\top \mathbf{e}(\mathbf{w}_k)) = 2\nabla \mathbf{e}(\mathbf{w}_k)^\top \mathbf{e}(\mathbf{w}_k). \quad (11.4.11)$$

利用迭代规则 (11.4.5) 以及界 (11.4.8a) 和 (11.4.9b),

$$\begin{aligned} \|\mathbf{w}_{k+1} - \mathbf{w}_k\| &= 2h\|\nabla \mathbf{e}(\mathbf{w}_k)^\top \mathbf{e}(\mathbf{w}_k)\| \\ &\leq 2h\sqrt{m}U\|\mathbf{e}(\mathbf{w}_k)\| \\ &\leq 2h\sqrt{m}U\|\mathbf{e}(\mathbf{w}_0)\|\rho^k. \end{aligned}$$

这证明了式 (11.4.9a) 对  $k+1$  成立. 特别地, 由式 (11.4.10),

$$\mathbf{w}_{k+1}, \mathbf{w}_k \in B_r(\mathbf{w}_0). \quad (11.4.12)$$

**步骤 3.** 证明式 (11.4.9b) 对  $k+1$  成立. 将  $\mathbf{e} : \mathbb{R}^n \rightarrow \mathbb{R}^m$  的分量记为  $e_1, \dots, e_m$ . 由于每个  $e_i$  都连续可微, 存在位于  $\mathbf{w}_k$  与  $\mathbf{w}_{k+1}$  凸包中的  $\tilde{\mathbf{w}}_k^i$ , 使得

$$\begin{aligned} e_i(\mathbf{w}_{k+1}) &= e_i(\mathbf{w}_k) + \int_0^1 \nabla e_i(\mathbf{w}_k + t(\mathbf{w}_{k+1} - \mathbf{w}_k))(\mathbf{w}_{k+1} - \mathbf{w}_k) dt \\ &= e_i(\mathbf{w}_k) + \nabla e_i(\tilde{\mathbf{w}}_k^i)^\top (\mathbf{w}_{k+1} - \mathbf{w}_k) \\ &= e_i(\mathbf{w}_k) - h\nabla e_i(\tilde{\mathbf{w}}_k^i)^\top \nabla F(\mathbf{w}_k). \end{aligned}$$

令  $\tilde{\mathbf{W}}_k := (\tilde{\mathbf{w}}_k^1, \dots, \tilde{\mathbf{w}}_k^m)$ . 由式 (11.4.11),

$$\begin{aligned} \mathbf{e}(\mathbf{w}_{k+1}) &= \mathbf{e}(\mathbf{w}_k) - 2h\nabla \mathbf{e}(\tilde{\mathbf{W}}_k)\nabla \mathbf{e}(\mathbf{w}_k)^\top \mathbf{e}(\mathbf{w}_k) \\ &= (\mathbf{I}_m - 2h\nabla \mathbf{e}(\tilde{\mathbf{W}}_k)\nabla \mathbf{e}(\mathbf{w}_k)^\top) \mathbf{e}(\mathbf{w}_k), \end{aligned}$$

其中  $\mathbf{I}_m \in \mathbb{R}^{m \times m}$  是单位矩阵. 我们要证明

$$\|\mathbf{I}_m - 2h\nabla \mathbf{e}(\tilde{\mathbf{W}}_k)\nabla \mathbf{e}(\mathbf{w}_k)^\top\| \leq \rho, \quad (11.4.13)$$

这便蕴含式 (11.4.9b) 对  $k+1$  成立, 并完成证明.

利用式 (11.4.8) 以及由式 (11.4.12) 得到的  $\mathbf{w}_k, \tilde{\mathbf{w}}_k^1, \dots, \tilde{\mathbf{w}}_k^m \in B_r(\mathbf{w}_0)$ , 有

$$\begin{aligned} &\|\nabla \mathbf{e}(\tilde{\mathbf{W}}_k)\nabla \mathbf{e}(\mathbf{w}_k)^\top - \nabla \mathbf{e}(\mathbf{w}_0)\nabla \mathbf{e}(\mathbf{w}_0)^\top\| \\ &\leq \|(\nabla \mathbf{e}(\tilde{\mathbf{W}}_k) - \nabla \mathbf{e}(\mathbf{w}_0))\nabla \mathbf{e}(\mathbf{w}_k)^\top\| \\ &\quad + \|\nabla \mathbf{e}(\mathbf{w}_0)(\nabla \mathbf{e}(\mathbf{w}_k) - \nabla \mathbf{e}(\mathbf{w}_0))^\top\| \\ &\leq 2mULr. \end{aligned}$$

由式 (11.4.7) 和假设 11.12(a),  $\nabla \mathbf{e}(\mathbf{w}_0)\nabla \mathbf{e}(\mathbf{w}_0)^\top$  的特征值属于  $[\theta_{\min}, \theta_{\max}]$ . 因此, 只要  $h \leq (\theta_{\min} + \theta_{\max})^{-1}$ , 就有

$$\begin{aligned} \|\mathbf{I}_m - 2h\nabla \mathbf{e}(\tilde{\mathbf{W}}_k)\nabla \mathbf{e}(\mathbf{w}_k)^\top\| &\leq \|\mathbf{I}_m - 2h\nabla \mathbf{e}(\mathbf{w}_0)\nabla \mathbf{e}(\mathbf{w}_0)^\top\| + 4hmULr \\ &\leq 1 - 2h\theta_{\min} + 4hmULr. \end{aligned}$$



由式 (11.4.3),

$$\begin{aligned} 1 - 2h\theta_{\min} + 4hmULr &\leq 1 - 2h\theta_{\min} + 4hmU \frac{\theta_{\min}^2}{8m^{3/2}U^2\sqrt{F(\mathbf{w}_0)}} \frac{2\sqrt{m}U\sqrt{F(\mathbf{w}_0)}}{\theta_{\min}} \\ &= 1 - h\theta_{\min} = \rho, \end{aligned}$$

从而完成证明.  $\square$

需要强调的是, 式 (11.4.6b) 意味着梯度下降法 (11.4.5) 在极限中达到零损失. 因而极限模型插值训练数据. 这特别说明, 对于极小化  $F(\mathbf{w})$  这一通常非凸的优化问题, 梯度下降法收敛到一个全局极小化子.

## 11.5 与训练后线性化模型的接近性

第 11.4 节的分析基于如下观察: 对于与初始参数  $\mathbf{w}_0$  的距离至多为  $r$  的参数 (参见假设 11.12), 线性化  $\Phi^{\text{lin}}$  能够很好地模拟完整模型  $\Phi$  的行为. 定理 11.13 指出, 在整个训练过程中, 参数都保持在这一范围内. 这表明, 训练后完整模型的预测  $\lim_{k \rightarrow \infty} \Phi(\mathbf{x}, \mathbf{w}_k)$  应当与训练后线性模型的预测  $\lim_{k \rightarrow \infty} \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k)$  相近. 本节将这一陈述形式化.

### 11.5.1 模型预测的演化

我们再次采用式 (11.3.1) 中的记号  $\Phi^{\text{lin}}: \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ , 表示  $\Phi: \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$  在  $\mathbf{w}_0$  附近的线性化. 线性化模型的参数记为  $\mathbf{p} \in \mathbb{R}^n$ , 相应的损失函数如式 (11.3.3) 所示, 记为  $F^{\text{lin}}(\mathbf{p})$ . 此外, 定义  $\mathbf{X} := (\mathbf{x}_1, \dots, \mathbf{x}_m)$ ; 对  $\widetilde{\mathbf{W}} = (\widetilde{\mathbf{w}}^1, \dots, \widetilde{\mathbf{w}}^m)$ , 令

$$\begin{aligned} \Phi(\mathbf{X}, \widetilde{\mathbf{W}}) &:= (\Phi(\mathbf{x}_i, \widetilde{\mathbf{w}}^i))_{i=1}^m \in \mathbb{R}^m, \\ \Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}) &:= (\Phi^{\text{lin}}(\mathbf{x}_i, \mathbf{p}))_{i=1}^m \in \mathbb{R}^m, \end{aligned}$$

以表示在给定参数  $\widetilde{\mathbf{w}}^1, \dots, \widetilde{\mathbf{w}}^m, \mathbf{p} \in \mathbb{R}^n$  时, 训练点  $\mathbf{x}_1, \dots, \mathbf{x}_m$  处的预测值. 另外,

$$\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \widetilde{\mathbf{W}}) = \begin{pmatrix} \nabla_{\mathbf{w}}\Phi(\mathbf{x}_1, \widetilde{\mathbf{w}}^1)^\top \\ \vdots \\ \nabla_{\mathbf{w}}\Phi(\mathbf{x}_m, \widetilde{\mathbf{w}}^m)^\top \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

当  $\widetilde{\mathbf{w}}^1 = \dots = \widetilde{\mathbf{w}}^m = \widetilde{\mathbf{w}}$  时, 我们简记为  $\Phi(\mathbf{X}, \widetilde{\mathbf{w}})$  和  $\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \widetilde{\mathbf{w}})$ . 类似地定义  $\nabla_{\mathbf{w}}\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p})$ . 采用这些记号, 模型在  $\mathbf{x} \in \mathbb{R}^d$  和  $\mathbf{X}$  处的预测在梯度下降法下按如下方式演化:

- **完整模型:** 从  $\mathbf{w}_0 \in \mathbb{R}^n$  初始化, 并对步长  $h > 0$  和所有  $k \in \mathbb{N}_0$  令

$$\mathbf{w}_{k+1} = \mathbf{w}_k - h\nabla_{\mathbf{w}}F(\mathbf{w}_k). \quad (11.5.1)$$

此时

$$\begin{aligned} \nabla_{\mathbf{w}}F(\mathbf{w}) &= \nabla_{\mathbf{w}}\|\Phi(\mathbf{X}, \mathbf{w}) - \mathbf{y}\|^2 \\ &= 2\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w})^\top (\Phi(\mathbf{X}, \mathbf{w}) - \mathbf{y}). \end{aligned}$$

因而

$$\begin{aligned}\Phi(\mathbf{x}, \mathbf{w}_{k+1}) &= \Phi(\mathbf{x}, \mathbf{w}_k) + \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}_k^{\mathbf{x}})^{\top}(\mathbf{w}_{k+1} - \mathbf{w}_k) \\ &= \Phi(\mathbf{x}, \mathbf{w}_k) - 2h\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}_k^{\mathbf{x}})^{\top}\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_k)^{\top}(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}),\end{aligned}$$

其中依赖于  $\mathbf{x}$  的某个  $\tilde{\mathbf{w}}_k^{\mathbf{x}} \in \mathbb{R}^n$  位于  $\mathbf{w}_k$  与  $\mathbf{w}_{k+1}$  的凸包中. 引入

$$\begin{aligned}\mathbf{G}^k(\mathbf{x}, \mathbf{X}) &:= \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}_k^{\mathbf{x}})^{\top}\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_k)^{\top} \in \mathbb{R}^{1 \times m}, \\ \mathbf{G}^k(\mathbf{X}, \mathbf{X}) &:= \nabla_{\mathbf{w}}\Phi(\mathbf{X}, \tilde{\mathbf{W}}_k^{\mathbf{X}})\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_k)^{\top} \in \mathbb{R}^{m \times m},\end{aligned}\tag{11.5.2}$$

其中  $\tilde{\mathbf{W}}_k^{\mathbf{X}} = (\tilde{\mathbf{w}}_k^{\mathbf{x}_1}, \dots, \tilde{\mathbf{w}}_k^{\mathbf{x}_m})$ , 便得到

$$\Phi(\mathbf{x}, \mathbf{w}_{k+1}) = \Phi(\mathbf{x}, \mathbf{w}_k) - 2h\mathbf{G}^k(\mathbf{x}, \mathbf{X})(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}),\tag{11.5.3a}$$

$$\Phi(\mathbf{X}, \mathbf{w}_{k+1}) = \Phi(\mathbf{X}, \mathbf{w}_k) - 2h\mathbf{G}^k(\mathbf{X}, \mathbf{X})(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}).\tag{11.5.3b}$$

- **线性化模型:** 从  $\mathbf{p}_0 := \mathbf{0} \in \mathbb{R}^n$  初始化, 并对步长  $h > 0$  和所有  $k \in \mathbb{N}_0$  令

$$\mathbf{p}_{k+1} = \mathbf{p}_k - h\nabla_{\mathbf{p}}F^{\text{lin}}(\mathbf{p}_k).\tag{11.5.4}$$

由于对任意  $\mathbf{p} \in \mathbb{R}^n$  都有  $\nabla_{\mathbf{p}}\Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}) = \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)$ , 故

$$\begin{aligned}\nabla_{\mathbf{p}}F^{\text{lin}}(\mathbf{p}) &= \nabla_{\mathbf{p}}\|\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}) - \mathbf{y}\|^2 \\ &= 2\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)^{\top}(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}) - \mathbf{y}),\end{aligned}$$

并且

$$\begin{aligned}\Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_{k+1}) &= \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k) + \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)^{\top}(\mathbf{p}_{k+1} - \mathbf{p}_k) \\ &= \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k) - 2h\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)^{\top}\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)^{\top}(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \mathbf{y}).\end{aligned}$$

引入 (参见式 (11.4.1))

$$\begin{aligned}\mathbf{G}^{\text{lin}}(\mathbf{x}, \mathbf{X}) &:= \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)^{\top}\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)^{\top} \in \mathbb{R}^{1 \times m}, \\ \mathbf{G}^{\text{lin}}(\mathbf{X}, \mathbf{X}) &:= \nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)^{\top} \\ &= (\hat{K}_n(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m \in \mathbb{R}^{m \times m},\end{aligned}\tag{11.5.5}$$

便得到

$$\Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_{k+1}) = \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k) - 2h\mathbf{G}^{\text{lin}}(\mathbf{x}, \mathbf{X})(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \mathbf{y}),\tag{11.5.6a}$$

$$\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_{k+1}) = \Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - 2h\mathbf{G}^{\text{lin}}(\mathbf{X}, \mathbf{X})(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \mathbf{y}).\tag{11.5.6b}$$

完整动力学 (11.5.3) 由依赖于  $k$  的核矩阵  $\mathbf{G}^k$  控制. 相比之下, 线性模型的动力学完全由初始核矩阵  $\mathbf{G}^{\text{lin}}$  决定. 下面的推论给出了这些矩阵在训练过程中可能偏离程度的上界, 见文献 [179, Thm. G.1].

**推论 11.14:** 令  $\mathbf{p}_0 = \mathbf{0} \in \mathbb{R}^n$ , 并设假设 11.12 对某些  $r, R, U, L, \theta_{\min}, \theta_{\max} > 0$  成立. 令  $(\mathbf{w}_k)_{k \in \mathbb{N}}$  和  $(\mathbf{p}_k)_{k \in \mathbb{N}}$  分别由梯度下降法 (11.5.1) 和 (11.5.4) 以正步长

$$h < \frac{1}{\theta_{\min} + \theta_{\max}}$$

生成. 则对所有满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\sup_{k \in \mathbb{N}} \|\mathbf{G}^k(\mathbf{x}, \mathbf{X}) - \mathbf{G}^{\text{lin}}(\mathbf{x}, \mathbf{X})\| \leq 2\sqrt{m}ULr, \quad (11.5.7a)$$

$$\sup_{k \in \mathbb{N}} \|\mathbf{G}^k(\mathbf{X}, \mathbf{X}) - \mathbf{G}^{\text{lin}}(\mathbf{X}, \mathbf{X})\| \leq 2mULr. \quad (11.5.7b)$$

**证明:** 由定理 11.13, 对所有  $k \in \mathbb{N}$  都有  $\mathbf{w}_k \in B_r(\mathbf{w}_0)$ . 因此, 对式 (11.5.2) 中位于  $\mathbf{w}_k$  与  $\mathbf{w}_{k+1}$  凸包内的  $\tilde{\mathbf{w}}_k^x$ , 也有  $\tilde{\mathbf{w}}_k^x \in B_r(\mathbf{w}_0)$ . 利用假设 11.12(b) 以及  $\mathbf{G}^k$  与  $\mathbf{G}^{\text{lin}}$  的定义,

$$\begin{aligned} & \|\mathbf{G}^k(\mathbf{x}, \mathbf{X}) - \mathbf{G}^{\text{lin}}(\mathbf{x}, \mathbf{X})\| \\ & \leq \|\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}_k^x)\| \|\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_k) - \nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)\| \\ & \quad + \|\nabla_{\mathbf{w}}\Phi(\mathbf{X}, \mathbf{w}_0)\| \|\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \tilde{\mathbf{w}}_k^x) - \nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)\| \\ & \leq 2\sqrt{m}ULr. \end{aligned}$$

第二个不等式的证明类似. □

### 11.5.2 极限模型预测

先陈述本节的主要结果. 它基于并遵循文献 [179, Thm. H.1] 中的论证, 给出了每个训练步上完整模型与线性化模型之差的上界, 因而也给出了极限中的上界.

**定理 11.15:** 考虑推论 11.14 的设定, 特别地, 令  $r, R, \theta_{\min}, \theta_{\max}$  如假设 11.12 所示. 则对所有满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\sup_{k \in \mathbb{N}} |\Phi(\mathbf{x}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k)| \leq \frac{4\sqrt{m}ULr}{\theta_{\min}} \left(1 + \frac{2mU^2}{\theta_{\min}}\right) \sqrt{F(\mathbf{w}_0)}.$$

为了证明该定理, 我们先考察完整模型与线性化模型在训练数据上的差.

**命题 11.16:** 考虑推论 11.14 的设定, 并令

$$\alpha := 4hmULr\sqrt{F(\mathbf{w}_0)}.$$

则对所有  $k \in \mathbb{N}$ ,

$$\|\Phi(\mathbf{X}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k)\| \leq \alpha k(1 - h\theta_{\min})^{k-1}.$$

**证明:** 在本证明中, 简记

$$\mathbf{G}^k = \mathbf{G}^k(\mathbf{X}, \mathbf{X}) \quad \text{且} \quad \mathbf{G}^{\text{lin}} = \mathbf{G}^{\text{lin}}(\mathbf{X}, \mathbf{X}),$$

并对  $k \in \mathbb{N}$  令

$$\mathbf{e}_k := \Phi(\mathbf{X}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k).$$

用式 (11.5.3b) 减去式 (11.5.6b), 对  $k \geq 0$  得

$$\begin{aligned} \mathbf{e}_{k+1} &= \mathbf{e}_k - 2h\mathbf{G}^k(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}) + 2h\mathbf{G}^{\text{lin}}(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \mathbf{y}) \\ &= (\mathbf{I}_m - 2h\mathbf{G}^{\text{lin}})\mathbf{e}_k - 2h(\mathbf{G}^k - \mathbf{G}^{\text{lin}})(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}), \end{aligned}$$

其中  $\mathbf{I}_m \in \mathbb{R}^{m \times m}$  是单位矩阵. 令  $\rho := 1 - h\theta_{\min}$ . 由式 (11.5.7b) 和 (11.4.6b), 第二项可估计为

$$\|2h(\mathbf{G}^k - \mathbf{G}^{\text{lin}})(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y})\| \leq \underbrace{4hmULr\sqrt{F(\mathbf{w}_0)}}_{=\alpha} \rho^k.$$

此外, 假设 11.12(a) 与  $h < (\theta_{\min} + \theta_{\max})^{-1}$  给出

$$\|\mathbf{I}_m - 2h\mathbf{G}^{\text{lin}}\| \leq 1 - 2h\theta_{\min} \leq \rho.$$

因此

$$\begin{aligned} \|\mathbf{e}_{k+1}\| &\leq \rho\|\mathbf{e}_k\| + \alpha\rho^k \leq \dots \leq \rho^{k+1}\|\mathbf{e}_0\| + \sum_{j=0}^k \rho^{k-j}\alpha\rho^j \\ &= \rho^{k+1}\|\mathbf{e}_0\| + \alpha(k+1)\rho^k. \end{aligned}$$

由于  $\mathbf{p}_0 = \mathbf{0}$ , 由式 (11.3.1) 有  $\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_0) = \Phi(\mathbf{X}, \mathbf{w}_0)$ . 因此  $\|\mathbf{e}_0\| = 0$ , 这便给出命题结论.  $\square$

现在可以证明该定理.

**定理 11.15的证明:** 在本证明中, 简记

$$\mathbf{G}^k = \mathbf{G}^k(\mathbf{x}, \mathbf{X}) \in \mathbb{R}^{1 \times m} \quad \text{且} \quad \mathbf{G}^{\text{lin}} = \mathbf{G}^{\text{lin}}(\mathbf{x}, \mathbf{X}) \in \mathbb{R}^{1 \times m},$$

并对  $k \in \mathbb{N}$  令

$$\mathbf{e}_k := \Phi(\mathbf{x}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k).$$

用式 (11.5.3a) 减去式 (11.5.6a), 得到

$$\begin{aligned} \mathbf{e}_{k+1} &= \mathbf{e}_k - 2h\mathbf{G}^k(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}) + 2h\mathbf{G}^{\text{lin}}(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \mathbf{y}) \\ &= \mathbf{e}_k - 2h(\mathbf{G}^k - \mathbf{G}^{\text{lin}})(\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}) + 2h\mathbf{G}^{\text{lin}}(\Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k) - \Phi(\mathbf{X}, \mathbf{w}_k)). \end{aligned}$$

记  $\rho := 1 - h\theta_{\min}$ . 由式 (11.5.7a) 和 (11.4.6b),

$$\begin{aligned} 2h\|\mathbf{G}^k - \mathbf{G}^{\text{lin}}\| &\leq 4h\sqrt{m}ULr, \\ \|\Phi(\mathbf{X}, \mathbf{w}_k) - \mathbf{y}\| &\leq \rho^k\sqrt{F(\mathbf{w}_0)}. \end{aligned}$$

由式 (11.4.2a) (参见式 (11.5.5)) 和命题 11.16,

$$\begin{aligned} 2h\|\mathbf{G}^{\text{lin}}\| &\leq 2h\sqrt{m}U^2, \\ \|\Phi(\mathbf{X}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{X}, \mathbf{p}_k)\| &\leq \alpha k \rho^{k-1}. \end{aligned}$$

因此, 对  $k \geq 0$ ,

$$|e_{k+1}| \leq |e_k| + \underbrace{4h\sqrt{m}ULr\sqrt{F(\mathbf{w}_0)}}_{=:\beta_1} \rho^k + \underbrace{2h\sqrt{m}U^2\alpha}_{=:\beta_2} k \rho^{k-1}.$$

反复应用此界, 并利用  $\sum_{j \geq 0} \rho^j = (1 - \rho)^{-1} = (h\theta_{\min})^{-1}$  和  $\sum_{j \geq 0} j \rho^{j-1} = (1 - \rho)^{-2} = (h\theta_{\min})^{-2}$ , 可得

$$\begin{aligned} |e_{k+1}| &\leq |e_0| + \beta_1 \sum_{j=0}^k \rho^j + \beta_2 \sum_{j=0}^k j \rho^{j-1} \\ &\leq \frac{\beta_1}{h\theta_{\min}} + \frac{\beta_2}{(h\theta_{\min})^2}. \end{aligned}$$

这里用到了如下事实: 由于  $\mathbf{p}_0 = \mathbf{0}$ , 有  $\Phi(\mathbf{x}, \mathbf{w}_0) = \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_0)$ , 故  $e_0 = 0$ .  $\square$

## 11.6 浅层神经网络的训练动力学

本节依照文献 [179], 讨论定理 11.13 和 11.15 对于宽神经网络的意义. 与文献 [308] 一样, 为便于表述, 我们聚焦于仅含一个隐藏层的浅层架构; 但需要强调, 类似的考量也适用于深层网络, 参见本章的文献与延伸阅读.

### 11.6.1 架构

令  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}$  为一个深度为一、宽度为  $n \in \mathbb{N}$  的神经网络, 其形式为

$$\Phi(\mathbf{x}, \mathbf{w}) = \mathbf{v}^\top \sigma(\mathbf{U}\mathbf{x} + \mathbf{b}) + c. \quad (11.6.1)$$

这里  $\mathbf{x} \in \mathbb{R}^d$  是输入, 而  $\mathbf{U} \in \mathbb{R}^{n \times d}$ 、 $\mathbf{v} \in \mathbb{R}^n$ 、 $\mathbf{b} \in \mathbb{R}^n$  和  $c \in \mathbb{R}$  是参数; 我们将它们汇集为向量  $\mathbf{w} = (\mathbf{U}, \mathbf{b}, \mathbf{v}, c) \in \mathbb{R}^{n(d+2)+1}$  (其中对  $\mathbf{U}$  作适当的形状重排). 为后续引用, 注意

$$\begin{aligned} \nabla_{\mathbf{U}} \Phi(\mathbf{x}, \mathbf{w}) &= (\mathbf{v} \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b})) \mathbf{x}^\top \in \mathbb{R}^{n \times d}, \\ \nabla_{\mathbf{b}} \Phi(\mathbf{x}, \mathbf{w}) &= \mathbf{v} \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) \in \mathbb{R}^n, \\ \nabla_{\mathbf{v}} \Phi(\mathbf{x}, \mathbf{w}) &= \sigma(\mathbf{U}\mathbf{x} + \mathbf{b}) \in \mathbb{R}^n, \\ \nabla_c \Phi(\mathbf{x}, \mathbf{w}) &= 1 \in \mathbb{R}, \end{aligned} \quad (11.6.2)$$

其中  $\odot$  表示 Hadamard 乘积. 我们还用  $\nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}) \in \mathbb{R}^{n(d+2)+1}$  表示关于全部参数的完整梯度.

实践中通常对权重作随机初始化; 本节考虑所谓的 LeCun 初始化 (LeCun initialization) [177]. 本章余下部分始终假设激活函数  $\sigma$  和初始化所用的  $\mathbb{R}$  上分布  $\mathcal{W}$  满足下述条件. 特别地, 该条件蕴含  $\sigma \in C^1$  至多线性增长, 且  $\mathcal{W}$  具有有限四阶矩; 这里不追求最大的普适性.

**假设 11.17:** 存在  $1 \leq R < \infty$ , 使得:

(a)  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  满足  $|\sigma(0)|, |\sigma'(0)|, \text{Lip}(\sigma), \text{Lip}(\sigma') \leq R$ ;

(b)  $\mathcal{W}$  的期望为零、方差为一, 并具有直至四阶的有限矩.

**注 11.18:** 本章余下部分中的常数通常依赖于  $\mathcal{W}(0, 1)$ , 以后不再逐一说明.  $\diamond$

为了在记号中明确标出期望和方差, 我们也用  $\mathcal{W}(0, 1)$  代替  $\mathcal{W}$ ; 对于  $\mu \in \mathbb{R}$  和  $\varsigma > 0$ , 用  $\mathcal{W}(\mu, \varsigma^2)$  表示相应的经缩放和平移后、期望为  $\mu$  且方差为  $\varsigma^2$  的测度. 因而, 若  $X \sim \mathcal{W}(0, 1)$ , 则  $\mu + \varsigma X \sim \mathcal{W}(\mu, \varsigma^2)$ . LeCun 初始化把每一层权重的方差设为该层输入维数的倒数, 其思想是对网络所有节点的输出方差作归一化. 因此, 初始参数

$$\mathbf{w}_0 = (\mathbf{U}_0, \mathbf{b}_0, \mathbf{v}_0, c_0)$$

的各分量随机初始化为

$$U_{0;ij} \stackrel{\text{iid}}{\sim} \mathcal{W}\left(0, \frac{1}{d}\right), \quad v_{0;i} \stackrel{\text{iid}}{\sim} \mathcal{W}\left(0, \frac{1}{n}\right), \quad b_{0;i}, c_0 = 0, \quad (11.6.3)$$

并且对所有  $i = 1, \dots, n, j = 1, \dots, d$  相互独立. 对固定的  $\varsigma > 0$ , 也可以在式 (11.6.3) 中选择方差  $\varsigma^2/d$  和  $\varsigma^2/n$ ; 这只需对本节余下内容作少量修改. 为简单起见, 偏置设为零, 习题中将讨论非零初始化. 第 11.6 节中的所有期望和概率均相对于这一随机初始化理解.

**例 11.19:**  $\mathcal{W}(0, 1)$  的典型例子是  $\mathbb{R}$  上的标准正态分布, 或  $[-\sqrt{3}, \sqrt{3}]$  上的均匀分布.  $\diamond$

### 11.6.2 神经切线核

我们首先研究具有初始化 11.6.3 的浅层网络 (11.6.1) 的经验切线核

$$\hat{K}_n(\mathbf{x}, \mathbf{z}) = \langle \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}_0), \nabla_{\mathbf{w}} \Phi(\mathbf{z}, \mathbf{w}_0) \rangle.$$

经过适当缩放后, 当宽度趋于无穷, 即  $n \rightarrow \infty$  时, 它收敛到一个称为神经切线核 (neural tangent kernel) (NTK) [147] 的特定核. 需要强调的是, 这一核同时依赖于网络架构和初始化方案. 下文只关注第 11.6.1 节所引入的特定设定, 因此将其简记为  $K^{\text{NTK}}$ .

**定理 11.20:** 设  $\sigma, \mathcal{W}$  对某个  $R \geq 0$  满足假设 11.17. 对任意  $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ , 若  $u_i \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1/d)$ ,  $i = 1, \dots, d$ , 则几乎必然有

$$\lim_{n \rightarrow \infty} \frac{1}{n} \hat{K}_n(\mathbf{x}, \mathbf{z}) = \mathbb{E}[\sigma(\mathbf{u}^\top \mathbf{x}) \sigma(\mathbf{u}^\top \mathbf{z})] =: K^{\text{NTK}}(\mathbf{x}, \mathbf{z}). \quad (11.6.4)$$

此外, 对每个  $\delta, \varepsilon > 0$ , 存在  $n_0(\delta, \varepsilon, R) \in \mathbb{N}$ , 使得对所有  $n \geq n_0$  以及所有满足  $\|\mathbf{x}\|, \|\mathbf{z}\| \leq R$  的  $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ , 都有

$$\mathbb{P} \left[ \left\| \frac{1}{n} \hat{K}_n(\mathbf{x}, \mathbf{z}) - K^{\text{NTK}}(\mathbf{x}, \mathbf{z}) \right\| < \varepsilon \right] \geq 1 - \delta.$$

**证明：** 记预激活值为  $\bar{\mathbf{x}}^{(1)} = \mathbf{U}_0 \mathbf{x} + \mathbf{b}_0 \in \mathbb{R}^n$  和  $\bar{\mathbf{z}}^{(1)} = \mathbf{U}_0 \mathbf{z} + \mathbf{b}_0 \in \mathbb{R}^n$ . 由初始化 (11.6.3) 以及对  $\mathcal{W}(0, 1)$  的假设, 各分量

$$\bar{x}_i^{(1)} = \sum_{j=1}^d U_{0;ij} x_j \sim \mathbf{u}^\top \mathbf{x}, \quad i = 1, \dots, n,$$

相互独立同分布, 并且对所有  $1 \leq p \leq 4$  都具有有限的  $p$  阶矩 (与  $n$  无关). 对  $(\sigma(\bar{x}_i^{(1)}))_{i=1}^n$  和  $(\sigma'(\bar{x}_i^{(1)}))_{i=1}^n$  也同样成立, 因为假设 11.17(a) 蕴含线性增长界

$$|\sigma(x)| \leq R(1 + |x|) \quad \text{且} \quad |\sigma'(x)| \leq R(1 + |x|), \quad \text{对所有 } x \in \mathbb{R}.$$

类似地,  $(\sigma(\bar{z}_i^{(1)}))_{i=1}^n$  和  $(\sigma'(\bar{z}_i^{(1)}))_{i=1}^n$  也分别是相互独立同分布的随机变量族, 并且对所有  $1 \leq p \leq 4$  都具有有限的  $p$  阶矩.

记  $\tilde{v}_i = \sqrt{n} v_{0;i}$ , 于是  $\tilde{v}_i \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1)$ . 由式 (11.6.2),

$$\begin{aligned} \frac{1}{n} \hat{K}_n(\mathbf{x}, \mathbf{z}) &= (1 + \mathbf{x}^\top \mathbf{z}) \frac{1}{n^2} \sum_{i=1}^n \tilde{v}_i^2 \sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)}) \\ &\quad + \frac{1}{n} \sum_{i=1}^n \sigma(\bar{x}_i^{(1)}) \sigma(\bar{z}_i^{(1)}) + \frac{1}{n}. \end{aligned} \quad (11.6.5)$$

由于

$$\frac{1}{n} \sum_{i=1}^n \tilde{v}_i^2 \sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)}) \quad (11.6.6)$$

是有限方差的独立同分布随机变量的平均值 (这来自矩条件, 以及  $\tilde{v}_i$  与  $\sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)})$  相互独立), 大数定律表明, 该式几乎必然收敛到

$$\begin{aligned} \mathbb{E}[\tilde{v}_i^2 \sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)})] &= \mathbb{E}[\tilde{v}_i^2] \mathbb{E}[\sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)})] \\ &= \mathbb{E}[\sigma'(\mathbf{u}^\top \mathbf{x}) \sigma'(\mathbf{u}^\top \mathbf{z})], \end{aligned}$$

其中用到了  $\tilde{v}_i^2$  与  $\sigma'(\bar{x}_i^{(1)}) \sigma'(\bar{z}_i^{(1)})$  相互独立. 因此, 当  $n \rightarrow \infty$  时, 式 (11.6.5) 右端第一项趋于零.

由同样的论证, 当  $n \rightarrow \infty$  时, 几乎必然有

$$\frac{1}{n} \sum_{i=1}^n \sigma(\bar{x}_i^{(1)}) \sigma(\bar{z}_i^{(1)}) \longrightarrow \mathbb{E}[\sigma(\mathbf{u}^\top \mathbf{x}) \sigma(\mathbf{u}^\top \mathbf{z})].$$

这证明了第一条结论.  $n_0$  的存在性可类似地由定理 A.23 推出.  $\square$

**注 11.21：** 在当前的 LeCun 初始化下, 定理 11.20 的证明中含  $\sigma'$  的那一项没有贡献. 关于能产生包含导数项的核的初始化, 参见文献 [147]; 文献中常把由此得到的核称为 NTK 核, 而式 (11.6.4) 也称为 NNGP 核 (NNGP kernel).  $\diamond$



**例 11.22** (ReLU 的  $K^{\text{NTK}}$ ): 令  $\sigma(x) = \max\{0, x\}$ , 并令  $\mathcal{W}(0, 1)$  为标准正态分布. 对  $\mathbf{x}, \mathbf{z} \in \mathbb{R}^d$ , 记

$$\vartheta = \arccos\left(\frac{\mathbf{x}^\top \mathbf{z}}{\|\mathbf{x}\| \|\mathbf{z}\|}\right)$$

为这两个向量之间的夹角. 由文献 [61, 附录 A], 若  $u_i \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1/d)$ ,  $i = 1, \dots, d$ , 则

$$\begin{aligned} K^{\text{NTK}}(\mathbf{x}, \mathbf{z}) &= \mathbb{E}[\sigma(\mathbf{u}^\top \mathbf{x}) \sigma(\mathbf{u}^\top \mathbf{z})] \\ &= \frac{\|\mathbf{x}\| \|\mathbf{z}\|}{2\pi d} (\sin(\vartheta) + (\pi - \vartheta) \cos(\vartheta)). \end{aligned}$$

◇

### 11.6.3 训练动力学与模型预测

下面依照文献 [179, 附录 G] 的方法, 说明在随机初始化 (11.6.3) 下, 第 11.4–11.5 节的分析以高概率适用于宽神经网络 (11.6.1). 我们对训练数据采用以下假设 [179, 假设 1–4]. 为避免引入更多常数, 仍使用  $R$  (与假设 11.17 中相同), 并在下文假设  $R$  足够大, 使假设 11.17 和 11.23 均成立.

**假设 11.23:** 存在  $1 \leq R < \infty$  和  $0 < \theta_{\min}^{\text{NTK}} \leq \theta_{\max}^{\text{NTK}} < \infty$ , 使得:

- (a) 对所有训练数据  $(\mathbf{x}_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ ,  $i = 1, \dots, m$ , 都有  $\|\mathbf{x}_i\|, |y_i| \leq R$ ;
- (b) 神经切线核的核矩阵

$$(K^{\text{NTK}}(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m \in \mathbb{R}^{m \times m}$$

可逆, 且其特征值属于  $[\theta_{\min}^{\text{NTK}}, \theta_{\max}^{\text{NTK}}]$ .

我们先在当前设定下验证假设 11.12(a). 更确切地说, 下面给出经验切线核特征值的界.

**引理 11.24:** 设假设 11.17、11.23 成立. 则对每个  $\delta > 0$ , 存在  $n_0(\delta, \theta_{\min}^{\text{NTK}}, m, R) \in \mathbb{R}$ , 使得对所有  $n \geq n_0$ , 以下事件以至少  $1 - \delta$  的概率发生: 矩阵

$$(\hat{K}_n(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m = (\langle \nabla_{\mathbf{w}} \Phi(\mathbf{x}_i, \mathbf{w}_0), \nabla_{\mathbf{w}} \Phi(\mathbf{x}_j, \mathbf{w}_0) \rangle)_{i,j=1}^m \in \mathbb{R}^{m \times m}$$

的所有特征值均属于  $[n\theta_{\min}^{\text{NTK}}/2, 2n\theta_{\max}^{\text{NTK}}]$ .

**证明:** 记  $\hat{\mathbf{G}}_n := (\hat{K}_n(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m$  和  $\mathbf{G}^{\text{NTK}} := (K^{\text{NTK}}(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^m$ . 由定理 11.20, 存在  $n_0$ , 使得对所有  $n \geq n_0$ , 以下不等式以至少  $1 - \delta$  的概率成立:

$$\left\| \mathbf{G}^{\text{NTK}} - \frac{1}{n} \hat{\mathbf{G}}_n \right\| \leq \frac{\theta_{\min}^{\text{NTK}}}{2}.$$

假设此界成立，则对称矩阵  $\hat{\mathbf{G}}_n/n$  的最小奇异值有下界

$$\begin{aligned} \inf_{\substack{\mathbf{a} \in \mathbb{R}^m \\ \|\mathbf{a}\|=1}} \frac{1}{n} \|\hat{\mathbf{G}}_n \mathbf{a}\| &\geq \inf_{\substack{\mathbf{a} \in \mathbb{R}^m \\ \|\mathbf{a}\|=1}} \|\mathbf{G}^{\text{NTK}} \mathbf{a}\| - \frac{\theta_{\min}^{\text{NTK}}}{2} \\ &\geq \theta_{\min}^{\text{NTK}} - \frac{\theta_{\min}^{\text{NTK}}}{2} \geq \frac{\theta_{\min}^{\text{NTK}}}{2}. \end{aligned}$$

这里用到  $\theta_{\min}^{\text{NTK}}$  是对称正定矩阵  $\mathbf{G}^{\text{NTK}}$  的最小特征值，因而也是其最小奇异值。正定矩阵的奇异值与特征值相同，故这表明（以至少  $1 - \delta$  的概率） $\hat{\mathbf{G}}_n$  的最小特征值不小于  $n\theta_{\min}^{\text{NTK}}/2$ 。类似地，最大特征值从上方被  $n(\theta_{\max}^{\text{NTK}} + \theta_{\min}^{\text{NTK}}/2) \leq 2n\theta_{\max}^{\text{NTK}}$  所界。证明完毕。  $\square$

下面验证假设 11.12(b)。为此先给出一个随机矩阵范数的简单界，它足以用于后续结果。

**引理 11.25:** 设  $\mathcal{W}$  满足假设 11.17(b)，并令  $\mathbf{W} \in \mathbb{R}^{n \times d}$ ，其中  $W_{ij} \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1)$ 。将  $\mathcal{W}(0, 1)$  的四阶矩记为  $\mu_4$ 。则

$$\mathbb{P} \left[ \|\mathbf{W}\| \leq \sqrt{n(d+1)} \right] \geq 1 - \frac{d\mu_4}{n}.$$

**证明:** 有

$$\|\mathbf{W}\| \leq \|\mathbf{W}\|_F = \left( \sum_{i=1}^n \sum_{j=1}^d W_{ij}^2 \right)^{1/2}.$$

令  $\alpha_i := \sum_{j=1}^d W_{ij}^2$ ， $i = 1, \dots, n$ 。它们相互独立同分布，期望为  $d$ ，方差为有限值  $dC$ ，其中  $C \leq \mu_4$  是  $W_{11}^2$  的方差。由定理 A.23，

$$\begin{aligned} \mathbb{P} \left[ \|\mathbf{W}\| > \sqrt{n(d+1)} \right] &\leq \mathbb{P} \left[ \frac{1}{n} \sum_{i=1}^n \alpha_i > d+1 \right] \\ &\leq \mathbb{P} \left[ \left| \frac{1}{n} \sum_{i=1}^n \alpha_i - d \right| > 1 \right] \leq \frac{d\mu_4}{n}, \end{aligned}$$

这便完成了证明。  $\square$

**引理 11.26:** 设假设 11.17(a) 对某个常数  $R \geq 1$  成立。则存在  $M(R)$ ；并且对所有  $\gamma, \delta > 0$ ，存在  $n_0(\gamma, \delta, d, R) \in \mathbb{N}$ ，使得对每个  $n \geq n_0$  和每个满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$ ，以下不等式以至少  $1 - \delta$  的概率成立：

$$\begin{aligned} \|\nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w})\| &\leq M\sqrt{n}, & \text{对所有 } \mathbf{w} \in B_{\gamma n^{-1/2}}(\mathbf{w}_0), \\ \|\nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{v})\| &\leq M\sqrt{n}\|\mathbf{w} - \mathbf{v}\|, & \text{对所有 } \mathbf{w}, \mathbf{v} \in B_{\gamma n^{-1/2}}(\mathbf{w}_0). \end{aligned}$$

**证明:** 由初始化 (11.6.3) 和引理 11.25，可以找到  $\tilde{n}_0(\delta, d)$ ，使得对所有  $n \geq \tilde{n}_0$ ，以下事件以至少  $1 - \delta$  的概率发生：

$$\|\mathbf{v}_0\| \leq 2 \quad \text{且} \quad \|\mathbf{U}_0\| \leq 2\sqrt{n}. \quad (11.6.7)$$

在本证明余下部分, 任取满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$ , 令

$$n_0 := \max\{\gamma^2, \tilde{n}_0(\delta, d)\},$$

并固定  $n \geq n_0$ , 从而  $n^{-1/2}\gamma \leq 1$ . 为证明引理, 只需说明只要式 (11.6.7) 成立, 所声称的不等式便成立. 下文将多次使用: 对所有  $\mathbf{p}, \mathbf{q} \in \mathbb{R}^n$ ,

$$\|\mathbf{p} \odot \mathbf{q}\| \leq \|\mathbf{p}\| \|\mathbf{q}\| \quad \text{且} \quad \|\sigma(\mathbf{p})\| \leq R\sqrt{n} + R\|\mathbf{p}\|,$$

这是因为由假设 11.17(a), 有  $|\sigma(x)| \leq R(1 + |x|)$ . 对  $\sigma'$  也有相同结论.

**步骤 1.** 证明梯度的界. 固定

$$\mathbf{w} = (\mathbf{U}, \mathbf{b}, \mathbf{v}, c) \quad \text{使得} \quad \|\mathbf{w} - \mathbf{w}_0\| \leq \gamma n^{-1/2}.$$

利用式 (11.6.2) 中  $\nabla_{\mathbf{b}}\Phi$  的公式、式 (11.6.3) 给出的  $\mathbf{b}_0 = \mathbf{0}$  以及上述不等式,

$$\begin{aligned} \|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w})\| &\leq \|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w}_0)\| + \|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w}_0)\| \\ &= \|\mathbf{v}_0 \odot \sigma'(\mathbf{U}_0\mathbf{x})\| + \|\mathbf{v} \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) - \mathbf{v}_0 \odot \sigma'(\mathbf{U}_0\mathbf{x})\| \\ &\leq 2(R\sqrt{n} + 2R^2\sqrt{n}) + \|\mathbf{v} \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) - \mathbf{v}_0 \odot \sigma'(\mathbf{U}_0\mathbf{x})\|. \end{aligned} \quad (11.6.8)$$

由于

$$\|\mathbf{U}\| \leq \|\mathbf{U}_0\| + \|\mathbf{U}_0 - \mathbf{U}\|_F \leq 2\sqrt{n} + \gamma n^{-1/2} \leq 3\sqrt{n}, \quad (11.6.9)$$

并且  $\sigma'$  的 Lipschitz 常数为  $R$ , 故式 (11.6.8) 中最后一个范数从上方被

$$\begin{aligned} &\|(\mathbf{v} - \mathbf{v}_0) \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b})\| + \|\mathbf{v}_0 \odot (\sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) - \sigma'(\mathbf{U}_0\mathbf{x}))\| \\ &\leq \gamma n^{-1/2}(R\sqrt{n} + R(\|\mathbf{U}\|\|\mathbf{x}\| + \|\mathbf{b}\|)) + 2R(\|\mathbf{U} - \mathbf{U}_0\|\|\mathbf{x}\| + \|\mathbf{b}\|) \\ &\leq R\sqrt{n} + 3\sqrt{n}R^2 + \gamma n^{-1/2}R + 2R(\gamma n^{-1/2}R + \gamma n^{-1/2}) \\ &\leq \sqrt{n}(4R + 5R^2) \end{aligned}$$

所界, 因此

$$\|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w})\| \leq \sqrt{n}(6R + 9R^2).$$

对于关于  $\mathbf{U}$  的梯度, 利用  $\nabla_{\mathbf{U}}\Phi(\mathbf{x}, \mathbf{w}) = \nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w})\mathbf{x}^\top$ , 得到

$$\begin{aligned} \|\nabla_{\mathbf{U}}\Phi(\mathbf{x}, \mathbf{w})\|_F &= \|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w})\mathbf{x}^\top\|_F \\ &= \|\nabla_{\mathbf{b}}\Phi(\mathbf{x}, \mathbf{w})\|\|\mathbf{x}\| \leq \sqrt{n}(6R^2 + 9R^3). \end{aligned}$$

接着,

$$\begin{aligned} \|\nabla_{\mathbf{v}}\Phi(\mathbf{x}, \mathbf{w})\| &= \|\sigma(\mathbf{U}\mathbf{x} + \mathbf{b})\| \\ &\leq R\sqrt{n} + R\|\mathbf{U}\mathbf{x} + \mathbf{b}\| \\ &\leq R\sqrt{n} + R(3\sqrt{n}R + \gamma n^{-1/2}) \\ &\leq \sqrt{n}(2R + 3R^2), \end{aligned}$$

最后  $\nabla_c \Phi(\mathbf{x}, \mathbf{w}) = 1$ . 总之, 令  $M_1(R) := 1 + 8R + 12R^2$ , 则

$$\|\nabla_{\mathbf{w}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\| \leq \sqrt{n} M_1(R).$$

**步骤 2.** 证明 Lipschitz 连续性. 固定

$$\mathbf{w} = (\mathbf{U}, \mathbf{b}, \mathbf{v}, c) \quad \text{和} \quad \tilde{\mathbf{w}} = (\tilde{\mathbf{U}}, \tilde{\mathbf{b}}, \tilde{\mathbf{v}}, \tilde{c}),$$

使得  $\|\mathbf{w} - \mathbf{w}_0\|, \|\tilde{\mathbf{w}} - \mathbf{w}_0\| \leq \gamma n^{-1/2}$ . 则

$$\begin{aligned} & \|\nabla_{\mathbf{b}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{b}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\| \\ &= \|\mathbf{v} \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) - \tilde{\mathbf{v}} \odot \sigma'(\tilde{\mathbf{U}}\mathbf{x} + \tilde{\mathbf{b}})\|. \end{aligned}$$

利用  $\|\tilde{\mathbf{v}}\| \leq \|\mathbf{v}_0\| + \gamma n^{-1/2} \leq 3$  和式 (11.6.9), 此项从上方被

$$\begin{aligned} & \|(\mathbf{v} - \tilde{\mathbf{v}}) \odot \sigma'(\mathbf{U}\mathbf{x} + \mathbf{b})\| + \|\tilde{\mathbf{v}} \odot (\sigma'(\mathbf{U}\mathbf{x} + \mathbf{b}) - \sigma'(\tilde{\mathbf{U}}\mathbf{x} + \tilde{\mathbf{b}}))\| \\ & \leq \|\mathbf{v} - \tilde{\mathbf{v}}\| (R\sqrt{n} + R(\|\mathbf{U}\|\|\mathbf{x}\| + \|\mathbf{b}\|)) \\ & \quad + 3R(\|\mathbf{x}\|\|\mathbf{U} - \tilde{\mathbf{U}}\| + \|\mathbf{b} - \tilde{\mathbf{b}}\|) \\ & \leq \|\mathbf{w} - \tilde{\mathbf{w}}\| \sqrt{n}(5R + 6R^2) \end{aligned}$$

所界. 对  $\nabla_{\mathbf{U}} \Phi(\mathbf{x}, \mathbf{w})$ , 与步骤 1 类似可得

$$\begin{aligned} & \|\nabla_{\mathbf{U}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{U}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\|_F \\ &= \|\mathbf{x}\| \|\nabla_{\mathbf{b}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{b}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\| \\ & \leq \|\mathbf{w} - \tilde{\mathbf{w}}\| \sqrt{n}(5R^2 + 6R^3). \end{aligned}$$

接着,

$$\begin{aligned} & \|\nabla_{\mathbf{v}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{v}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\| \\ &= \|\sigma(\mathbf{U}\mathbf{x} + \mathbf{b}) - \sigma(\tilde{\mathbf{U}}\mathbf{x} + \tilde{\mathbf{b}})\| \\ & \leq R(\|\mathbf{U} - \tilde{\mathbf{U}}\|\|\mathbf{x}\| + \|\mathbf{b} - \tilde{\mathbf{b}}\|) \\ & \leq \|\mathbf{w} - \tilde{\mathbf{w}}\|(R^2 + R), \end{aligned}$$

而  $\nabla_c \Phi(\mathbf{x}, \mathbf{w}) = 1$  为常数. 令  $M_2(R) := R + 6R^2 + 6R^3$ , 便有

$$\|\nabla_{\mathbf{w}} \Phi(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{w}} \Phi(\mathbf{x}, \tilde{\mathbf{w}})\| \leq \sqrt{n} M_2(R) \|\mathbf{w} - \tilde{\mathbf{w}}\|.$$

综上, 取  $M(R) := \max\{M_1(R), M_2(R)\}$  即完成证明.  $\square$

下面说明初始误差  $F(\mathbf{w}_0)$  以高概率保持有界.

**引理 11.27:** 设假设 11.17 和 11.23 成立. 则对每个  $\delta > 0$ , 存在  $R_0(\delta, m, R) > 0$ , 使得对所有  $n \in \mathbb{N}$ ,

$$\mathbb{P}[F(\mathbf{w}_0) \leq R_0] \geq 1 - \delta.$$

**证明：** 令  $i \in \{1, \dots, m\}$ , 并置  $\alpha := \mathbf{U}_0 \mathbf{x}_i$  以及  $\tilde{v}_j := \sqrt{n} v_{0;j}$ ,  $j = 1, \dots, n$ , 从而  $\tilde{v}_j \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1)$ . 此时

$$\Phi(\mathbf{x}_i, \mathbf{w}_0) = \frac{1}{\sqrt{n}} \sum_{j=1}^n \tilde{v}_j \sigma(\alpha_j).$$

由假设 11.17 和式 (11.6.3), 随机变量  $\tilde{v}_j \sigma(\alpha_j)$ ,  $j = 1, \dots, n$ , 相互独立同分布、均值为零, 且方差有限并被一个与  $n$  无关的常数  $C(R)$  所界. 因而  $\Phi(\mathbf{x}_i, \mathbf{w}_0)$  的方差也被  $C(R)$  所界. 由 Chebyshev 不等式 (见引理 A.22), 对每个  $k > 0$ ,

$$\mathbb{P}[|\Phi(\mathbf{x}_i, \mathbf{w}_0)| \geq k\sqrt{C}] \leq \frac{1}{k^2}.$$

令  $k = \sqrt{m/\delta}$ , 则

$$\begin{aligned} \mathbb{P} \left[ \sum_{i=1}^m |\Phi(\mathbf{x}_i, \mathbf{w}_0) - y_i|^2 \geq m(k\sqrt{C} + R)^2 \right] \\ \leq \sum_{i=1}^m \mathbb{P}[|\Phi(\mathbf{x}_i, \mathbf{w}_0) - y_i| \geq k\sqrt{C} + R] \\ \leq \sum_{i=1}^m \mathbb{P}[|\Phi(\mathbf{x}_i, \mathbf{w}_0)| \geq k\sqrt{C}] \leq \delta, \end{aligned}$$

这便以  $R_0 = m(\sqrt{Cm/\delta} + R)^2$  证明了结论.  $\square$

下面的定理对应文献 [179, 定理 G.1 和 H.1], 是本章的主要结果之一. 它概括了当前设定下宽度为  $n$  的浅层网络的结论: 以高概率, 梯度下降收敛到全局极小化子, 且极限网络插值数据. 训练期间网络权重始终接近初始化值. 训练后网络给出的预测与训练后线性化模型的预测相差  $O(n^{-1/2})$ . 在定理陈述中, 仍以  $\Phi^{\text{lin}}$  表示式 (11.3.1) 定义的  $\Phi$  的线性化, 并分别以  $F$ 、 $F^{\text{lin}}$  表示式 (11.0.1b)、(11.3.3) 定义的相应无岭平方损失目标函数.

**定理 11.28:** 设假设 11.17 和 11.23 成立, 并按照式 (11.6.3) 初始化式 (11.6.1) 中宽度为  $n$  的神经网络  $\Phi$  的参数  $\mathbf{w}_0$ . 固定正学习率

$$h \leq \frac{2}{n(\theta_{\min}^{\text{NTK}} + 4\theta_{\max}^{\text{NTK}})},$$

令  $\mathbf{p}_0 := \mathbf{0} \in \mathbb{R}^n$ , 并对所有  $k \in \mathbb{N}_0$  令

$$\mathbf{w}_{k+1} = \mathbf{w}_k - h \nabla F(\mathbf{w}_k) \quad \text{且} \quad \mathbf{p}_{k+1} = \mathbf{p}_k - h \nabla F^{\text{lin}}(\mathbf{p}_k).$$

则对每个  $\delta > 0$ , 存在  $C > 0$ 、 $n_0 \in \mathbb{N}$ , 使得对所有  $n \geq n_0$ , 以下结论以至少  $1 - \delta$  的概率对所有  $k \in \mathbb{N}$  以及所有满足  $\|\mathbf{x}\| \leq R$  的  $\mathbf{x} \in \mathbb{R}^d$  成立:

$$\|\mathbf{w}_k - \mathbf{w}_0\| \leq C \sqrt{\frac{F(\mathbf{w}_0)}{n}}, \quad (11.6.10a)$$

$$F(\mathbf{w}_k) \leq \left(1 - h \frac{n\theta_{\min}^{\text{NTK}}}{2}\right)^{2k} F(\mathbf{w}_0), \quad (11.6.10b)$$

$$\|\Phi(\mathbf{x}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k)\| \leq C \sqrt{\frac{F(\mathbf{w}_0)}{n}}. \quad (11.6.10c)$$

**证明：** 我们希望应用定理 11.13 和 11.15，为此需要验证假设 11.12.

固定  $\delta > 0$ ，并令  $R_0(\delta/2)$  如引理 11.27 所示，从而  $\sqrt{F(\mathbf{w}_0)} \leq \sqrt{R_0}$  以至少  $1 - \delta/2$  的概率成立. 再令  $M = M(R)$  如引理 11.26 所示，并选取

$$n_{0,1} = n_{0,1}(\delta, R, \theta_{\min}^{\text{NTK}}) \in \mathbb{N} \quad \text{和} \quad \gamma = \gamma(\delta, m, R, \theta_{\min}^{\text{NTK}}) > 0$$

足够大，使得对所有  $n \geq n_{0,1}$ ，

$$M\sqrt{n} \leq \frac{n^2(\theta_{\min}^{\text{NTK}}/2)^2}{8m^{3/2}M^2n\sqrt{R_0}}, \quad \gamma n^{-1/2} \geq \frac{4\sqrt{m}M\sqrt{n}}{n\theta_{\min}^{\text{NTK}}} \sqrt{R_0}. \quad (11.6.11)$$

由引理 11.24 和 11.26，可以找到  $n_{0,2} = n_{0,2}(\delta, m, \theta_{\min}^{\text{NTK}}, R)$ ，使得对所有  $n \geq n_{0,2}$ ，假设 11.12(a)、(b) 以至少  $1 - \delta/2$  的概率对以下取值成立：

$$L = M\sqrt{n}, \quad U = M\sqrt{n}, \quad r = \frac{4\sqrt{m}M\sqrt{n}}{n\theta_{\min}^{\text{NTK}}} \sqrt{F(\mathbf{w}_0)}, \quad (11.6.12a)$$

以及

$$\theta_{\min} = \frac{n\theta_{\min}^{\text{NTK}}}{2}, \quad \theta_{\max} = 2n\theta_{\max}^{\text{NTK}}. \quad (11.6.12b)$$

结合式 (11.6.11) 可知，只要  $n \geq n_0 := \max\{n_{0,1}, n_{0,2}\}$ ，假设 11.12 就以至少  $1 - \delta$  的概率成立.

不等式 (11.6.10a)、(11.6.10b) 直接来自定理 11.13 以及式 (11.6.12a) 中  $r$  的定义. 对式 (11.6.10c)，将式 (11.6.12) 的取值代入定理 11.15 的界，便对  $k \in \mathbb{N}$  得到

$$\begin{aligned} \|\Phi(\mathbf{x}, \mathbf{w}_k) - \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k)\| &\leq \frac{4\sqrt{m}ULr}{\theta_{\min}} \left(1 + \frac{2mU^2}{\theta_{\min}}\right) \sqrt{F(\mathbf{w}_0)} \\ &\leq \frac{C_1}{\sqrt{n}}(1 + C_2)\sqrt{F(\mathbf{w}_0)}, \end{aligned}$$

其中  $C_1, C_2$  依赖于  $\delta, m, R, \theta_{\min}^{\text{NTK}}$ ，但与  $n$  无关. □

#### 11.6.4 与 Gaussian 过程和核最小二乘的联系

定理 11.28 表明，训练后的神经网络复现了训练后线性化模型的行为. 正如第 11.3 节指出的，训练后线性化模型的预测等于一个无岭最小二乘估计量再加上一项依赖随机初始化  $\mathbf{w}_0 \in \mathbb{R}^n$  选择的项. 因此，应把初始化时的模型  $\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_0)$  和训练后的模型  $\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_k)$  都理解为从某个函数分布中随机抽取的样本. 为进一步说明这一点，下面引入 Gaussian 过程.

**定义 11.29：** 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是一个概率空间（见第 A.1 节），并令  $g : \mathbb{R}^d \times \Omega \rightarrow \mathbb{R}$ . 若  $g$  具有均值函数（mean function） $\mu : \mathbb{R}^d \rightarrow \mathbb{R}$  和协方差函数（covariance function） $c : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ ，并满足：

- (a) 对每个  $\mathbf{x} \in \mathbb{R}^d$ ，映射  $\omega \mapsto g(\mathbf{x}, \omega)$  是随机变量；

(b) 对所有  $k \in \mathbb{N}$  和所有  $\mathbf{x}_1, \dots, \mathbf{x}_k \in \mathbb{R}^d$ , 随机变量  $g(\mathbf{x}_1, \cdot), \dots, g(\mathbf{x}_k, \cdot)$  联合服从 Gaussian 分布, 且

$$(g(\mathbf{x}_1, \omega), \dots, g(\mathbf{x}_k, \omega)) \sim \mathcal{N}((\mu(\mathbf{x}_i))_{i=1}^k, (c(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^k),$$

则称  $g$  是一个 Gaussian 过程 (Gaussian process) .

换言之, 若  $g$  是 Gaussian 过程, 则  $\omega \mapsto g(\mathbf{x}, \omega)$  定义了一个由  $\mathbf{x} \in \mathbb{R}^d$  标记的随机变量族, 并且  $(g(\mathbf{x}_j, \cdot))_{j=1}^k$  的联合分布为 Gaussian 分布, 其均值和协方差分别由  $\mu$  和  $c$  决定. 固定  $\omega \in \Omega$  后, 可以把  $\mathbf{x} \mapsto g(\mathbf{x}, \omega)$  解释为从函数分布中随机抽取的一个样本.

文献 [212] 最早观察到, 在无限宽极限下, 某些初始化后的神经网络趋于 Gaussian 过程. 为简单起见, 下面的命题沿用此前的设定, 并不追求关于  $\sigma$  和  $\mathcal{W}$  的最优假设.

**命题 11.30:** 设  $\sigma, \mathcal{W}$  满足假设 11.17. 考虑式 (11.6.1) 中具有初始化 (11.6.3) 的宽度为  $n$  的网络  $\Phi$ . 令  $K^{\text{NTK}}: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$  如定理 11.20 所示.

则对所有互异的  $\mathbf{x}_1, \dots, \mathbf{x}_k \in \mathbb{R}^d$ , 都有

$$\lim_{n \rightarrow \infty} (\Phi(\mathbf{x}_1, \mathbf{w}_0), \dots, \Phi(\mathbf{x}_k, \mathbf{w}_0)) \sim \mathcal{N}(\mathbf{0}, (K^{\text{NTK}}(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^k),$$

其中收敛是依分布收敛.

**证明:** 令  $\tilde{v}_i := \sqrt{n} v_{0,i}$ , 并令  $\tilde{\mathbf{u}}_i = (U_{0,i1}, \dots, U_{0,id}) \in \mathbb{R}^d$ , 于是  $\tilde{v}_i \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1)$ ;  $\tilde{\mathbf{u}}_i \in \mathbb{R}^d$  也相互独立同分布, 且其每个分量均服从  $\mathcal{W}(0, 1/d)$ .

对任意  $\mathbf{x}_1, \dots, \mathbf{x}_k$ , 令

$$\mathbf{Z}_i := \begin{pmatrix} \tilde{v}_i \sigma(\tilde{\mathbf{u}}_i^\top \mathbf{x}_1) \\ \vdots \\ \tilde{v}_i \sigma(\tilde{\mathbf{u}}_i^\top \mathbf{x}_k) \end{pmatrix} \in \mathbb{R}^k, \quad i = 1, \dots, n.$$

这定义了  $\mathbb{R}^k$  中  $n$  个均值为零、相互独立同分布且二阶矩有限的向量 (这里利用了假设 11.17 所保证的  $\sigma$  至多线性增长以及  $\mathcal{W}(0, 1)$  的有限二阶矩). 由中心极限定理 (见定理 A.25),

$$\begin{pmatrix} \Phi(\mathbf{x}_1, \mathbf{w}_0) \\ \vdots \\ \Phi(\mathbf{x}_k, \mathbf{w}_0) \end{pmatrix} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{Z}_i$$

依分布收敛到  $\mathcal{N}(\mathbf{0}, \mathbf{C})$ , 其中

$$\begin{aligned} C_{ij} &= \mathbb{E}[\tilde{v}_1^2 \sigma(\tilde{\mathbf{u}}_1^\top \mathbf{x}_i) \sigma(\tilde{\mathbf{u}}_1^\top \mathbf{x}_j)] \\ &= \mathbb{E}[\sigma(\tilde{\mathbf{u}}_1^\top \mathbf{x}_i) \sigma(\tilde{\mathbf{u}}_1^\top \mathbf{x}_j)] = K^{\text{NTK}}(\mathbf{x}_i, \mathbf{x}_j). \end{aligned}$$

证明完毕. □

**注 11.31:** 在当前设定下, 协方差函数由神经切线核给出. 对其他初始化方案, 这未必成立; 命题 11.30 中的协方差也称为 NNGP (neural network Gaussian process) 核; 另见本章文献部分. ◇



在命题 11.30 的意义下, 当宽度  $n$  趋于无穷时, 网络  $\Phi(\mathbf{x}, \mathbf{w}_0)$  收敛到一个 Gaussian 过程. 还可以证明, 训练后的线性化网络也对应于一个 Gaussian 过程, 其均值函数和协方差函数依赖于数据、架构和初始化. 由于完整模型与线性化模型在无限宽极限下一致 (见定理 11.28), 可以推断训练后的宽网络类似于从 Gaussian 过程中抽取的样本, 参见文献 [179, 第 2.3.1 节] 和 [74].

为了启发式地说明该 Gaussian 过程的均值, 再次考虑对充分小的学习率  $h > 0$  成立的式 (11.3.6). 利用式 (11.2.11) 中核最小二乘估计量的显式表达, 并令  $\Phi(\mathbf{X}, \mathbf{w}_0) := (\Phi(\mathbf{x}_j, \mathbf{w}_0))_{j=1}^m \in \mathbb{R}^m$ , 则对任意  $\mathbf{x} \in \mathbb{R}^d$ ,

$$\lim_{k \rightarrow \infty} \Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k) = \Phi(\mathbf{x}, \mathbf{w}_0) + \hat{K}_n(\mathbf{x}, \mathbf{X}) \hat{K}_n(\mathbf{X}, \mathbf{X})^{-1} (\mathbf{y} - \Phi(\mathbf{X}, \mathbf{w}_0)).$$

由定理 11.20, 当  $n \rightarrow \infty$  时,  $\hat{K}_n/n \rightarrow K^{\text{NTK}}$ . 因此, 对大的  $n$ , 最后一个表达式近似于

$$\Phi(\mathbf{x}, \mathbf{w}_0) + K^{\text{NTK}}(\mathbf{x}, \mathbf{X}) K^{\text{NTK}}(\mathbf{X}, \mathbf{X})^{-1} (\mathbf{y} - \Phi(\mathbf{X}, \mathbf{w}_0)). \quad (11.6.13)$$

式 (11.6.13) 是  $\Phi(\cdot, \mathbf{w}_0)$  的线性变换, 而后者本身表现得像一个 Gaussian 过程.

考虑式 (11.6.13) 的均值 (关于  $\mathbf{w}_0$  的随机初始化). 由命题 11.30, 当  $n$  很大时,  $\mathbb{E}[\Phi(\mathbf{x}, \mathbf{w}_0)] \simeq 0$ . 实际上, 正如该命题的证明所示, 即使对任意有限的  $n$ , 也有  $\mathbb{E}[\Phi(\mathbf{x}, \mathbf{w}_0)] = 0$ . 对式 (11.6.13) 取期望, 得到

$$K^{\text{NTK}}(\mathbf{x}, \mathbf{X}) K^{\text{NTK}}(\mathbf{X}, \mathbf{X})^{-1} \mathbf{y}.$$

由注 11.10, 这正是神经切线核对应的无岭核最小二乘估计量. 因此, 当宽度  $n$  和训练步数  $k$  都很大时, 预期有

$$\mathbb{E}[\Phi(\mathbf{x}, \mathbf{w}_k)] \simeq \mathbb{E}[\Phi^{\text{lin}}(\mathbf{x}, \mathbf{p}_k)] \simeq \text{以 } K^{\text{NTK}} \text{ 为核的无岭核最小二乘估计量在 } \mathbf{x} \text{ 处的取值}. \quad (11.6.14)$$

换言之, 在充分训练后, 训练后神经网络  $\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_k)$  关于随机初始化所取的均值, 近似于以  $K^{\text{NTK}}$  为核的核最小二乘估计量. 因而, 在这些假设下, 我们明确刻画了经梯度下降训练后的网络预测. 更多细节以及协方差函数的精确刻画仍参见文献 [179, 第 2.3.1 节].

下面用一个实验直观展示上述观察. 图 11.3 绘出了神经网络在训练前后的 80 个不同实现, 即函数

$$\mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_0) \quad \text{和} \quad \mathbf{x} \mapsto \Phi(\mathbf{x}, \mathbf{w}_k). \quad (11.6.15)$$

架构取为式 (11.6.1), 激活函数为  $\sigma(x) = \arctan(x)$ , 宽度为  $n = 250$ , 初始化为

$$U_{0;ij} \stackrel{\text{iid}}{\sim} \text{N}\left(0, \frac{3}{d}\right), \quad v_{0;i} \stackrel{\text{iid}}{\sim} \text{N}\left(0, \frac{3}{n}\right), \quad b_{0;i}, c_0 \stackrel{\text{iid}}{\sim} \text{N}(0, 2). \quad (11.6.16)$$

为获得更好的可视化效果, 这里对初始化 (11.6.3) 作了轻微修改. 网络在无岭平方损失

$$F(\mathbf{w}) = \sum_{j=1}^m (\Phi(\mathbf{x}_j, \mathbf{w}) - y_j)^2$$

上训练；数据集大小为  $m = 3$ ，使用常步长  $h = 1/n$  进行  $k = 5000$  步梯度下降。训练前，网络输出类似于从具有恒零均值函数的 Gaussian 过程中随机抽取的样本。训练后，输出在训练点处的方差最小，因为它们基本插值数据，这与定理 11.28，特别是式 (11.6.10b) 的预期一致。在训练点之外，可以观察到增大的方差。由式 (11.6.14)，其均值应接近以  $K^{\text{NTK}}$  为核的无岭核最小二乘估计量。




图 11.3: 神经网络在初始化时 (a) 以及在红色数据点上无正则化训练后 (b) 的 80 个实现。虚线表示均值。本图基于文献 [147, 图 2] 和 [179, 图 2]。

图 11.4 给出了采用岭正则化训练后的网络实现，即使用损失函数 (11.0.1c)。初始化和所有超参数均与图 11.3 相同，正则化参数取为  $\lambda = 0.01$ 。对线性模型，采用岭正则化训练后的预测应表现出更小的随机性，因为训练后的模型与无岭核最小二乘估计量相差  $O(\lambda)$ （见第 11.2.3 节）。需要指出，定理 11.15 关于训练后线性化模型与完整模型接近性的结论及其分析不能直接推广到岭正则化：正则化项引入了朝向  $\mathbf{0}$  的强偏置。因此，训练期间网络权重可能移出 NTK 区域。尽管如此，在这个例子中仍观察到类似效应。




图 11.4: 图 11.3 中的神经网络在红色数据点上加入岭正则化训练后的 80 个实现。虚线表示均值。

### 11.6.5 初始化的作用

考虑 LeCun 初始化 (11.6.3) 下式 (11.6.2) 中的梯度  $\nabla_{\mathbf{w}}\Phi(\mathbf{x}, \mathbf{w}_0)$ , 其中  $v_{0;i} \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1/n)$  且  $U_{0;ij} \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1/d)$ . 关于宽度  $n$ , 各梯度范数满足

$$\begin{aligned}\mathbb{E}[\|\nabla_U\Phi(\mathbf{x}, \mathbf{w}_0)\|^2] &= \mathbb{E}[\|(\mathbf{v}_0 \odot \sigma'(U_0\mathbf{x}))\mathbf{x}^\top\|^2] &&= O(1), \\ \mathbb{E}[\|\nabla_b\Phi(\mathbf{x}, \mathbf{w}_0)\|^2] &= \mathbb{E}[\|\mathbf{v}_0 \odot \sigma'(U_0\mathbf{x})\|^2] &&= O(1), \\ \mathbb{E}[\|\nabla_v\Phi(\mathbf{x}, \mathbf{w}_0)\|^2] &= \mathbb{E}[\|\sigma(U_0\mathbf{x})\|^2] &&= O(n), \\ \mathbb{E}[\|\nabla_c\Phi(\mathbf{x}, \mathbf{w}_0)\|^2] &= \mathbb{E}[1] &&= O(1).\end{aligned}$$

由于尺度不同, 采用定理 11.28 中  $O(n^{-1})$  的步长进行梯度下降时, 主要调整输出层的权重  $\mathbf{v}$ , 而其余参数  $\mathbf{U}$ 、 $\mathbf{b}$  和  $c$  只发生轻微变化. 这也反映在定理 11.20 所计算的核  $K^{\text{NTK}}$  的表达式中: 它只对应于  $\langle \nabla_v\Phi, \nabla_v\Phi \rangle$  一项的贡献.

LeCun 初始化 [177] 将权重初始化方差取为与每层输入维数成反比, 使所有节点输出的方差保持稳定, 不会随宽度增大而发散; 另见文献 [127]. 然而, 它并未归一化反向动力学 (backward dynamics), 也就是说, 它不能保证关于各参数的梯度具有相近的方差. 为了同时平衡前向动力学 (forward dynamics) 和反向动力学的归一化, Glorot 和 Bengio 提出了一种归一化初始化 (normalized initialization), 其中方差取为与每层输入维数和输出维数之和成反比 [106]; 见习题 11.39. 需要强调的是, 初始化的选择会显著影响神经切线核 (NTK), 进而影响训练动力学以及训练后网络的预测. 关于所谓的 NTK 初始化 (NTK initialization) (它不像本章的设定那样要求学习率以  $O(n^{-1})$  下降), 特别参见最初的 NTK 论文 [147]. 文献中所称的神经切线核通常就是在这一参数化下得到的核.

## 文献与延伸阅读

第 11.1 节和第 11.2 节中关于线性最小二乘与核最小二乘的讨论大多是标准内容, 也可在许多教科书中找到, 例如文献 [124, 285, 202, 14]. 关于最小二乘问题及其算法的更多细节, 见文献 [108, 37, 44, 221]; 关于计算伪逆的迭代算法, 例如见文献 [27, 239]; 关于不适定问题的正则化, 例如见文献 [92]. 表示定理最初由文献 [160] 引入, 文献 [277] 给出了更一般的版本. 一个易于理解的表述例如见文献 [285, 定理 16.1]. 核技巧通常归于文献 [40], 另见文献 [2, 69]. 关于核方法的更多细节, 见文献 [70, 278, 6]. 关于无岭核回归的泛化性质, 近期工作例如见文献 [185, 123, 21].

神经切线核及其与训练动力学的联系最初由文献 [147] 研究. 此后, 许多工作扩展了这一思想, 并从不同视角研究这一主题, 例如见文献 [5, 86, 10, 60]. 我们在第 11.3–11.6 节中的叙述以文献 [179] 为基础并紧密遵循该文, 尤其是这些节中的主要结果, 我们采用了该文的论证. 此外, 文献 [308, 第 8 章] 基于文献 [60], 对梯度流 (而非梯度下降) 给出了类似处理: 特别地, 与文献 [308] 一样, 我们只考虑浅层网络, 并先给出对任意函数参数化均有效的抽象分析, 再特化到神经网络. 我们还推荐 Bach 近期教科书 [14, 第 9.5 章]. 文献 [179] 以及上述若干文献也研究了深层架构的情形. 例 11.22 中给出的 ReLU 网络 NTK 显式公式来自文献 [61].

第 11.6.4 节讨论的神经网络在初始化时表现得像 Gaussian 过程这一观察，最初由文献 [212] 提出。关于 Gaussian 过程的一般性参考，见教科书 [257]。当只训练网络最后一层时（此时网络为仿射线性的），它与随机特征方法有很强的联系 [254]。近期关于这一主题的进展，也可在以“神经网络 Gaussian 过程”（简称 NNGP）为名的文献中找到 [178, 75]。

## 习题

### 11.32. 证明命题 11.4.

提示：先假设  $\mathbf{w}_0 \in \ker(\mathbf{A})^\perp$  (即  $\mathbf{w}_0 \in \tilde{H}$ ) . 对于  $\text{rank}(\mathbf{A}) < d$  的情形, 利用  $\mathbf{w}_k = \mathbf{w}_{k-1} - h\nabla F(\mathbf{w}_{k-1})$  和  $\mathbf{A}$  的奇异值分解, 写出  $\mathbf{w}_k$  的显式公式. 注意, 对所有  $x \in (0, 1)$  都有  $1/(1-x) = \sum_{k \in \mathbb{N}_0} x^k$ , 因而当  $k \rightarrow \infty$  时  $\mathbf{w}_k \rightarrow \mathbf{A}^\dagger \mathbf{y}$ , 其中  $\mathbf{A}^\dagger$  是  $\mathbf{A}$  的 Moore–Penrose 伪逆.

11.33. 设  $\mathbf{A} \in \mathbb{R}^{d \times d}$  对称半正定,  $\mathbf{b} \in \mathbb{R}^d$ ,  $c \in \mathbb{R}$ . 对  $\lambda > 0$ , 令

$$F(\mathbf{w}) := \mathbf{w}^\top \mathbf{A} \mathbf{w} + \mathbf{b}^\top \mathbf{w} + c, \quad F_\lambda(\mathbf{w}) := F(\mathbf{w}) + \lambda \|\mathbf{w}\|^2.$$

证明  $F$  是  $2\lambda$ -强凸的.

提示：使用习题 10.23.

11.34. 设  $(H, \langle \cdot, \cdot \rangle_H)$  为 Hilbert 空间,  $\phi: \mathbb{R}^d \rightarrow H$  为一个映射. 给定  $(\mathbf{x}_j, y_j)_{j=1}^m \in \mathbb{R}^d \times \mathbb{R}$ , 对  $\lambda > 0$  定义

$$F_\lambda(\mathbf{w}) := \sum_{j=1}^m (\langle \phi(\mathbf{x}_j), \mathbf{w} \rangle_H - y_j)^2 + \lambda \|\mathbf{w}\|_H^2 \quad \text{对所有 } \mathbf{w} \in H.$$

证明  $F_\lambda$  有唯一的极小化子  $\mathbf{w}_{*,\lambda} \in H$ , 且  $\mathbf{w}_{*,\lambda} \in \tilde{H} := \text{span}\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)\}$ , 并且  $\lim_{\lambda \rightarrow 0} \mathbf{w}_{*,\lambda} = \mathbf{w}_*$ , 其中  $\mathbf{w}_*$  如式 (11.2.3) 所示.

提示：先假设  $\mathbf{w}_{*,\lambda}$  存在, 并证明  $\mathbf{w}_{*,\lambda}$  属于有限维空间  $\tilde{H}$ . 再用  $\tilde{H}$  的一组标准正交基表示  $\mathbf{w}_{*,\lambda}$ , 并证明  $\mathbf{w}_{*,\lambda} \rightarrow \mathbf{w}_*$ .

11.35. 设  $\mathbf{x}_i \in \mathbb{R}^d$ ,  $i = 1, \dots, m$ . 证明存在一个“特征映射”  $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$ , 使得对标签  $y_i \in \{-1, 1\}$  的任意配置, 总存在  $\mathbb{R}^m$  中的一个超平面, 将两个集合  $\{\phi(\mathbf{x}_i) | y_i = 1\}$  和  $\{\phi(\mathbf{x}_i) | y_i = -1\}$  分隔开.

11.36. 设  $n \in \mathbb{N}$ , 考虑多项式核  $K: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ ,  $K(\mathbf{x}, \mathbf{z}) = (1 + \mathbf{x}^\top \mathbf{z})^n$ . 求 Hilbert 空间  $H$  和特征映射  $\phi: \mathbb{R}^d \rightarrow H$ , 使得  $K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle_H$ .

提示：使用多项式定理

$$(x_1 + \dots + x_k)^n = \sum_{\substack{\boldsymbol{\nu} \in \mathbb{N}_0^k \\ |\boldsymbol{\nu}| = n}} \frac{n!}{\nu_1! \dots \nu_k!} x_1^{\nu_1} \dots x_k^{\nu_k}.$$

11.37. 设  $\lambda > 0$ ,  $K$  为一个核 (见定义 11.9), 并设  $\boldsymbol{\alpha} \in \mathbb{R}^m$  为式 (11.2.7) 中的一个极小化子. 证明此时式 (11.2.10) 成立.

11.38. 考虑网络 (11.6.1), 其中  $\mathbf{U}$  和  $\mathbf{v}$  按式 (11.6.3) 初始化, 但偏置改为

$$c, b_i \stackrel{\text{iid}}{\sim} \mathcal{W}(0, 1) \quad \text{对所有 } i = 1, \dots, n. \quad (11.6.17)$$

像定理 11.28 那样计算相应的 NTK.

11.39. 考虑网络 (11.6.1), 其初始化为

$$U_{0;ij} \stackrel{\text{iid}}{\sim} \mathcal{W}\left(0, \frac{1}{d+n}\right), \quad v_{0;i} \stackrel{\text{iid}}{\sim} \mathcal{W}\left(0, \frac{1}{n+1}\right), \quad b_{0;i}, c_0 = 0.$$

像定理 11.28 那样计算相应的 NTK.

## 损失景观分析

在第 10 章中, 我们已经看到如何在训练期间使用梯度下降法的各种变体调整神经网络的权重. 在某些情形下, 包括第 11 章所考虑的宽网络, 相应的迭代格式会收敛到全局极小化子. 一般而言, 这并无保证; 例如, 梯度下降可能困在非全局极小值或鞍点处.

为了更好地理解这些情形, 本章讨论所谓的损失景观 (loss landscape). 这一术语指经验风险作为权重函数时的图像. 下面将给出更严格的定义, 并先为具有固定架构的神经网络及其实现引入记号.

**定义 12.1:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  为激活函数, 并设  $B > 0$ . 将如下神经网络  $\Phi$  的集合记为  $\mathcal{N}(\sigma; \mathcal{A}, B)$ : 它们有  $L$  层, 各层宽度为  $d_0, d_1, \dots, d_{L+1}$ , 所有权重的绝对值都不超过  $B$ , 并使用激活函数  $\sigma$ . 此外, 定义

$$\mathcal{PN}(\mathcal{A}, B) := \bigtimes_{\ell=0}^L ([-B, B]^{d_{\ell+1} \times d_{\ell}} \times [-B, B]^{d_{\ell+1}}),$$

以及实现映射 (realization map)

$$\begin{aligned} R_{\sigma}: \mathcal{PN}(\mathcal{A}, B) &\longrightarrow \mathcal{N}(\sigma; \mathcal{A}, B), \\ \mathbf{w} &\longmapsto \Phi(\cdot, \mathbf{w}), \end{aligned} \tag{12.0.1}$$

其中,  $\Phi(\cdot, \mathbf{w})$  是由权重和偏置  $\mathbf{w} = (\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})_{\ell=0}^L$  确定的神经网络, 如定义 2.1 所示.

下文始终将  $\mathcal{PN}(\mathcal{A}, B)$  与立方体  $[-B, B]^{n_{\mathcal{A}}}$  等同, 其中  $n_{\mathcal{A}} := \sum_{\ell=0}^L d_{\ell+1}(d_{\ell} + 1)$ . 现在可以引入神经网络架构的损失景观.

**定义 12.2:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 设  $m \in \mathbb{N}$ ,  $S = (\mathbf{x}_i, \mathbf{y}_i)_{i=1}^m \in (\mathbb{R}^{d_0} \times \mathbb{R}^{d_{L+1}})^m$  为一个样本,  $\mathcal{L}$  为一个损失函数. 则损失景观是函数  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  的图像, 该函数定义为

$$\begin{aligned} \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}: \mathcal{PN}(\mathcal{A}; \infty) &\longrightarrow \mathbb{R}, \\ \theta &\longmapsto \widehat{\mathcal{R}}_S(R_{\sigma}(\theta)), \end{aligned}$$

其中  $\widehat{\mathcal{R}}_S$  见式 (1.3),  $R_{\sigma}$  见式 (12.0.1).

将  $\mathcal{PN}(\mathcal{A}, \infty)$  与  $\mathbb{R}^{n_{\mathcal{A}}}$  等同后, 可以把  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  视为  $\mathbb{R}^{n_{\mathcal{A}}}$  上的映射, 而损失景观则是  $\mathbb{R}^{n_{\mathcal{A}}} \times \mathbb{R}$  的一个子集. 损失景观是一个具有山峰和谷地的高维曲面. 为便于可视化, 图 12.1 给出了损失景观的一个二维截面.

关于损失景观, 我们感兴趣的问题例如包括: 找到局部极小值而非全局极小值的可能性有多大? 这些局部极小值通常是体积很小的尖锐极小值, 还是难以逃离的大型平坦






图 12.1: 损失景观的二维截面. 该损失景观展示了一个具有局部极小值的伪谷、全局极小值、出现鞍点的区域, 以及一个尖锐极小值.

谷地的一部分? 落入局部极小值的后果有多严重? 大多数局部极小值是否与全局极小值一样深, 还是可能高得多? 该曲面总体上有多粗糙, 而且这些特征如何依赖于网络架构? 一般而言, 要完整回答这些问题很困难; 在本章的余下部分, 我们将针对具体情形给出一些直观和数学见解.

## 12.1 损失景观的可视化

损失景观的可视化可以为理解神经网络的深度、宽度和激活函数所产生的影响提供宝贵见解. 然而, 我们至多只能把嵌入三维空间的二维曲面可视化, 而损失景观是一个极高维对象 (除非神经网络只有极少的权重和偏置).

为了使损失景观便于观察, 需要降低其维数. 这可以通过在  $\mathcal{PN}(\mathcal{A}, \infty)$  的一个二维子空间上计算函数  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  来实现. 具体而言, 选取三个参数  $\mu, \theta_1, \theta_2$ , 并考察函数

$$\mathbb{R}^2 \ni (\alpha_1, \alpha_2) \mapsto \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\mu + \alpha_1 \theta_1 + \alpha_2 \theta_2). \quad (12.1.1)$$

$\mu, \theta_1, \theta_2$  有如下几种自然的选取方式:

- 随机方向: 例如, 文献 [112, 143] 采用了这种方法. 其中  $\theta_1, \theta_2$  随机选取, 而  $\mu$  或者取为  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  的一个极小化子, 或者也随机选取. 这种简单方法可以快速揭示曲面可能有多粗糙. 然而, 正如文献 [182] 所指出的, 随机方向极有可能与优化过程的轨迹正交, 因而很可能会错过最相关的特征.



- 学习轨迹的主成分：为弥补随机方向的不足，另一种可能是确定最能刻画给定学习轨迹的  $\mu, \theta_1, \theta_2$ . 例如，若  $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$  是使用 SGD 训练所得的参数，则可以确定  $\mu, \theta_1, \theta_2$ ，使超平面

$$\{\mu + \alpha_1 \theta_1 + \alpha_2 \theta_2 \mid \alpha_1, \alpha_2 \in \mathbb{R}\}$$

到  $\theta^{(j)}$  ( $j \in \{1, \dots, N\}$ ) 的均方距离最小. 这是文献 [182] 所采用的方法，可通过主成分分析实现.

- 基于临界点：为了获得更具全局性的视角，可以选取  $\mu, \theta_1, \theta_2$ ，以保证观察到多个临界点. 一种做法是将优化过程运行三次，得到最终参数  $\theta^{(1)}, \theta^{(2)}, \theta^{(3)}$ . 若这些过程均已收敛，则每个参数都接近  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  的一个临界点. 此时可令  $\mu = \theta^{(1)}, \theta_1 = \theta^{(2)} - \mu, \theta_2 = \theta^{(3)} - \mu$ . 这样便可保证式 (12.1.1) 经过或至少非常接近三个临界点（对应  $(\alpha_1, \alpha_2) = (0, 0), (0, 1), (1, 0)$ ）. 图 12.2 给出了六个这种形式的可视化结果.

图 12.2 为深度和宽度如何影响损失景观的形状提供了一些有趣见解. 对于很宽且很浅的神经网络，极小值附近的区域最宽；使用双曲正切激活函数时，这些极小值看起来还属于同一个谷地. 随着深度增加而宽度减小，极小值附近变得更陡，也更加彼此分离.

## 12.2 伪谷

从优化的角度来看，理想的损失景观在一个大谷地的中心只有一个全局极小值，从而无论选择何种初始化，梯度下降法都会向这个极小值收敛.

这种情形对深度神经网络并不现实. 事实上，对于一个简单的浅层神经网络

$$\mathbb{R}^d \ni \mathbf{x} \mapsto \Phi(\mathbf{x}) = \mathbf{W}^{(1)} \sigma(\mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}) + \mathbf{b}^{(1)},$$

显然，对每个置换矩阵  $\mathbf{P}$ ，都有

$$\Phi(\mathbf{x}) = \mathbf{W}^{(1)} \mathbf{P}^T \sigma(\mathbf{P} \mathbf{W}^{(0)} \mathbf{x} + \mathbf{P} \mathbf{b}^{(0)}) + \mathbf{b}^{(1)} \quad \text{对所有 } \mathbf{x} \in \mathbb{R}^d.$$

因此，一般存在多个实现同一输出函数的参数化. 此外，若至少存在一个权重不具有置换不变性的全局极小值，则损失景观中不止有一个全局极小值.

这并不是问题；事实上，存在许多全局极小值是有益的. 更大的问题在于非全局极小值的存在. 遵循文献 [317]，我们先把非全局极小值的概念推广为伪谷.

**定义 12.3:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ，且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 设  $m \in \mathbb{N}$ ,  $S = (\mathbf{x}_i, \mathbf{y}_i)_{i=1}^m \in (\mathbb{R}^{d_0} \times \mathbb{R}^{d_{L+1}})^m$  为一个样本， $\mathcal{L}$  为一个损失函数. 对  $c \in \mathbb{R}$ ，定义  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  的次水平集为

$$\Omega_{\Lambda}(c) := \{\theta \in \mathcal{PN}(\mathcal{A}, \infty) \mid \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta) \leq c\}.$$

$\Omega_{\Lambda}(c)$  中不包含  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  的全局极小值的路径连通分支，称为一个伪谷 (spurious valley).

下一个命题表明，对浅层过参数化神经网络，不存在伪局部极小值；也就是说，隐藏层中的参数至少与训练样本一样多。

**命题 12.4:** 设  $\mathcal{A} = (d_0, d_1, 1) \in \mathbb{N}^3$ ,  $S = (\mathbf{x}_i, y_i)_{i=1}^m \in (\mathbb{R}^{d_0} \times \mathbb{R})^m$  为满足  $m \leq d_1$  的样本. 此外, 设  $\sigma \in \mathcal{M}$  不是多项式,  $\mathcal{L}$  为凸损失函数. 再假设  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  至少有一个全局极小值. 则  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  没有伪谷.

**证明:** 设  $\theta_a, \theta_b \in \mathcal{PN}(\mathcal{A}, \infty)$  满足  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_a) > \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_b)$ . 下面将证明存在另一个参数  $\theta_c$ , 使得

- $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_b) \geq \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_c)$ ;
- 存在连续路径  $\alpha: [0, 1] \rightarrow \mathcal{PN}(\mathcal{A}, \infty)$ , 使得  $\alpha(0) = \theta_a$ ,  $\alpha(1) = \theta_c$ , 并且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha)$  单调递减.

由习题 12.7, 在上述构造中取  $\theta_a$  为伪谷中的一个元素、 $\theta_b$  为全局极小值, 便可排除伪谷的存在.

下面给出这一构造. 记

$$\theta_o = \left( (\mathbf{W}_o^{(\ell)}, \mathbf{b}_o^{(\ell)})_{\ell=0}^1 \right) \quad \text{对 } o \in \{a, b, c\}.$$

此外, 对  $j = 1, \dots, d_1$ , 引入  $\mathbf{v}_o^j \in \mathbb{R}^m$ , 其定义为

$$(\mathbf{v}_o^j)_i = (\sigma(\mathbf{W}_o^{(0)} \mathbf{x}_i + \mathbf{b}_o^{(0)}))_j \quad \text{对 } i = 1, \dots, m.$$

注意, 若令  $\mathbf{V}_o = ((\mathbf{v}_o^j)^\top)_{j=1}^{d_1}$ , 则

$$\mathbf{W}_o^{(1)} \mathbf{V}_o = (R_\sigma(\theta_o)(\mathbf{x}_i) - \mathbf{b}_o^{(1)})_{i=1}^m, \quad (12.2.1)$$

其中右端视为行向量.

现在分两种情形讨论. 第一种情形下结论是直接的, 第二种情形可以转化为第一种.

**情形 1:** 假设  $\mathbf{V}_a$  的秩为  $m$ . 此时由式 (12.2.1) 显然存在  $\widetilde{\mathbf{W}}$ , 使得

$$\widetilde{\mathbf{W}} \mathbf{V}_a = (R_\sigma(\theta_b)(\mathbf{x}_i) - \mathbf{b}_a^{(1)})_{i=1}^m.$$

因此可令  $\alpha(t) = ((\mathbf{W}_a^{(0)}, \mathbf{b}_a^{(0)}), ((1-t)\mathbf{W}_a^{(1)} + t\widetilde{\mathbf{W}}, \mathbf{b}_a^{(1)}))$ . 由构造可知  $\alpha(0) = \theta_a$ , 且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha(1)) = \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_b)$ . 此外,  $t \mapsto (R_\sigma(\alpha(t))(\mathbf{x}_i))_{i=1}^m$  描述了  $\mathbb{R}^m$  中的一条直线路径, 因而由  $\mathcal{L}$  的凸性可知,  $t \mapsto \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha(t))$  在  $[0, 1]$  上于某个  $t^*$  处取得极小值, 并且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha(t^*)) \leq \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\theta_b)$ . 而且,  $t \mapsto \Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha(t))$  在  $[0, t^*]$  上单调递减. 令  $\theta_c = \alpha(t^*)$  即完成这一情形.

**情形 2:** 假设  $\mathbf{V}_a$  的秩小于  $m$ . 此时, 我们证明存在一条从  $\theta_a$  到另一个秩更高的神经网络参数的连续路径, 并且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  沿该路径单调递减.

在这些假设下, 某个  $\mathbf{v}_a^j$  可以写成其余  $\mathbf{v}_a^i$  ( $i \neq j$ ) 的线性组合. 不失一般性, 假设  $j = 1$ . 于是存在  $(\alpha_i)_{i=2}^m$ , 使得

$$\mathbf{v}_a^1 = \sum_{i=2}^m \alpha_i \mathbf{v}_a^i. \quad (12.2.2)$$

接下来注意到, 存在  $\mathbf{v}^* \in \mathbb{R}^m$ , 它与所有  $(\mathbf{v}_a^j)_{j=1}^m$  线性无关, 并且对某个  $\mathbf{w}^* \in \mathbb{R}^{d_0}$ ,  $b^* \in \mathbb{R}$ , 可写成  $(\mathbf{v}^*)_i = \sigma((\mathbf{w}^*)^\top \mathbf{x}_i + b^*)$ . 事实上, 若不存在这样的  $\mathbf{v}^*$ , 则对所有  $\mathbf{w} \in \mathbb{R}^{d_0}$ ,  $b \in \mathbb{R}$ , 向量  $(\sigma(\mathbf{w}^\top \mathbf{x}_i + b))_{i=1}^m$  都属于同一个  $m-1$  维子空间. 于是  $\text{span}\{(\sigma(\mathbf{w}^\top \mathbf{x}_i + b))_{i=1}^m \mid \mathbf{w} \in \mathbb{R}^{d_0}, b \in \mathbb{R}\}$  是  $\mathbb{R}^m$  的一个  $m-1$  维子空间, 这与定理 9.3 矛盾.

现在定义两条路径. 首先, 令

$$\alpha_1(t) = ((\mathbf{W}_a^{(0)}, \mathbf{b}_a^{(0)}), (\mathbf{W}_a^{(1)}(t), \mathbf{b}_a^{(1)})), \quad t \in [0, 1/2],$$

其中

$$\begin{aligned} (\mathbf{W}_a^{(1)}(t))_1 &= (1-2t)(\mathbf{W}_a^{(1)})_1, \\ (\mathbf{W}_a^{(1)}(t))_i &= (\mathbf{W}_a^{(1)})_i + 2t\alpha_i(\mathbf{W}_a^{(1)})_1, \quad i = 2, \dots, d_1, \quad t \in [0, 1/2]. \end{aligned}$$

其次, 令

$$\alpha_2(t) = ((\mathbf{W}_a^{(0)}(t), \mathbf{b}_a^{(0)}(t)), (\mathbf{W}_a^{(1)}(1/2), \mathbf{b}_a^{(1)})), \quad t \in (1/2, 1],$$

其中

$$\begin{aligned} (\mathbf{W}_a^{(0)}(t))_1 &= 2(t-1/2)(\mathbf{W}_a^{(0)})_1 + (2t-1)\mathbf{w}^*, \\ (\mathbf{W}_a^{(0)}(t))_i &= (\mathbf{W}_a^{(0)})_i, \quad i = 2, \dots, d_1, \end{aligned}$$

并且  $(\mathbf{b}_a^{(0)}(t))_1 = 2(t-1/2)(\mathbf{b}_a^{(0)})_1 + (2t-1)b^*$ , 而对  $i = 2, \dots, d_1$ , 有  $(\mathbf{b}_a^{(0)}(t))_i = (\mathbf{b}_a^{(0)})_i$ .

由式 (12.2.2), 显然  $(R_\sigma(\alpha_1)(\mathbf{x}_i))_{i=1}^m$  为常量. 此外, 对所有  $\mathbf{x} \in \mathbb{R}^{d_0}$ ,  $R_\sigma(\alpha_2)(\mathbf{x})$  为常量. 再者, 由构造, 对

$$\bar{\mathbf{v}}^j := \left( \left( \sigma(\mathbf{W}_a^{(0)}(1)\mathbf{x}_i + \mathbf{b}_a^{(0)}(1)) \right)_j \right)_{i=1}^m,$$

$((\bar{\mathbf{v}}^j)^\top)_{j=1}^{d_1}$  的秩大于  $\mathbf{V}_a$  的秩. 连接  $\alpha_1$  与  $\alpha_2$ , 便得到一条从  $\theta_a$  到另一个具有更高相关秩的神经网络参数的连续路径, 并且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}$  沿该路径单调递减. 迭代这一构造, 可以找到一条通向某个神经网络参数的路径, 使其相关矩阵满秩. 这便把问题化归为情形 1.  $\square$

## 12.3 鞍点

鞍点是损失景观中的临界点, 损失沿某个方向在此下降. 从这个意义上说, 如果学习迭代的更新具有一定随机性, 那么鞍点不像局部极小值或伪谷那样棘手. 最终, 随机步骤可能沿正确方向迈出, 从而逃离鞍点.

如果大多数临界点都是鞍点, 那么即使损失景观给优化带来挑战, 最终到达全局极小值的机会仍然很大. 文献 [73, 234] 研究了损失景观中的鞍点, 下面将以简化方式回顾其中一些发现. 文献 [234] 的主要观察是, 在某些相当强的假设下, 损失景观中与较大损失相联系的临界点通常是鞍点, 而与较小损失相联系的临界点则对应于极小值. 这种情形对深度学习中的优化前景是有利的, 因为即使困在局部极小值处, 其损失也很可能接近最优值.

文献 [234] 的结果使用了随机矩阵理论, 这里不作回顾. 此外, 很难判断其中所作的假设对某个具体问题是否成立. 尽管如此, 下面回顾其主要思想, 为上述论断提供一些直观依据.

设  $\mathcal{A} = (d_0, d_1, 1) \in \mathbb{N}^3$ . 对神经网络参数  $\theta \in \mathcal{PN}(\mathcal{A}, \infty)$  和激活函数  $\sigma$ , 令  $\Phi_\theta := R_\sigma(\theta)$ ; 对样本  $S = (\mathbf{x}_i, y_i)_{i=1}^m$ , 定义误差

$$e_i = \Phi_\theta(\mathbf{x}_i) - y_i \quad \text{对 } i = 1, \dots, m.$$

若采用平方损失, 则

$$\widehat{\mathcal{R}}_S(\Phi_\theta) = \frac{1}{m} \sum_{i=1}^m e_i^2. \quad (12.3.1)$$

下面研究  $\widehat{\mathcal{R}}_S(\Phi_\theta)$  的 Hessian 矩阵.

**命题 12.5:** 设  $\mathcal{A} = (d_0, d_1, 1)$  且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 对每个使式 (12.3.1) 中的  $\widehat{\mathcal{R}}_S(\Phi_\theta)$  关于权重二次连续可微的  $\theta \in \mathcal{PN}(\mathcal{A}, \infty)$ , 都有

$$\mathbf{H}(\theta) = \mathbf{H}_0(\theta) + \mathbf{H}_1(\theta),$$

其中  $\mathbf{H}(\theta)$  是  $\widehat{\mathcal{R}}_S(\Phi_\theta)$  在  $\theta$  处的 Hessian 矩阵;  $\mathbf{H}_0(\theta)$  是与  $(y_i)_{i=1}^m$  无关的半正定矩阵;  $\mathbf{H}_1(\theta)$  是对称矩阵, 并且在固定  $\theta$  和  $(\mathbf{x}_i)_{i=1}^m$  时线性依赖于  $(e_i)_{i=1}^m$ .

**证明:** 利用定义 12.2 之后引入的等同关系, 可以把  $\theta$  视为  $\mathbb{R}^{n_A}$  中的向量. 对  $k = 1, \dots, n_A$ , 有

$$\frac{\partial \widehat{\mathcal{R}}_S(\Phi_\theta)}{\partial \theta_k} = \frac{2}{m} \sum_{i=1}^m e_i \frac{\partial \Phi_\theta(\mathbf{x}_i)}{\partial \theta_k}.$$

因此, 对  $j = 1, \dots, n_A$ , 由 Leibniz 法则可得

$$\begin{aligned} \frac{\partial^2 \widehat{\mathcal{R}}_S(\Phi_\theta)}{\partial \theta_j \partial \theta_k} &= \frac{2}{m} \sum_{i=1}^m \left( \frac{\partial \Phi_\theta(\mathbf{x}_i)}{\partial \theta_j} \frac{\partial \Phi_\theta(\mathbf{x}_i)}{\partial \theta_k} \right) + \frac{2}{m} \left( \sum_{i=1}^m e_i \frac{\partial^2 \Phi_\theta(\mathbf{x}_i)}{\partial \theta_j \partial \theta_k} \right) \\ &=: \mathbf{H}_0(\theta) + \mathbf{H}_1(\theta). \end{aligned} \quad (12.3.2)$$

还需证明  $\mathbf{H}_0(\theta)$  和  $\mathbf{H}_1(\theta)$  具有所断言的性质. 令

$$J_{i,\theta} = \begin{pmatrix} \frac{\partial \Phi_\theta(\mathbf{x}_i)}{\partial \theta_1} \\ \vdots \\ \frac{\partial \Phi_\theta(\mathbf{x}_i)}{\partial \theta_{n_A}} \end{pmatrix} \in \mathbb{R}^{n_A}.$$

于是  $\mathbf{H}_0(\theta) = \frac{2}{m} \sum_{i=1}^m J_{i,\theta} J_{i,\theta}^\top$ , 故  $\mathbf{H}_0(\theta)$  是若干半正定矩阵之和, 从而也是半正定的.

由于假设在  $\theta$  处二次连续可微, 二阶导数的对称性直接给出  $\mathbf{H}_1(\theta)$  的对称性. 由式 (12.3.2),  $\mathbf{H}_1(\theta)$  关于  $(e_i)_{i=1}^m$  的线性性是显然的.  $\square$

命题 12.5 如何推出所声称的损失大小与鞍点普遍程度之间的关系？

设  $\theta$  对应于一个临界点. 若  $\mathbf{H}(\theta)$  至少有一个负特征值, 则  $\theta$  不可能是极小值, 而必为鞍点或极大值. 除了知道  $\mathbf{H}_1(\theta)$  对称以外, 我们对它一无所知; 不过, 特别是在  $n_{\mathcal{A}}$  很大时, 假设它有负特征值并非不合理. 基于这一考虑, 考察如下模型.

固定参数  $\theta$ . 设  $S^0 = (\mathbf{x}_i, y_i^0)_{i=1}^m$  为一个样本,  $(e_i^0)_{i=1}^m$  为相应误差. 再令  $\mathbf{H}^0(\theta)$ 、 $\mathbf{H}_1^0(\theta)$  为命题 12.5 中的矩阵.

对  $\lambda > 0$ , 再设  $S^\lambda = (\mathbf{x}_i, y_i^\lambda)_{i=1}^m$ , 使得相应误差满足  $(e_i)_{i=1}^m = \lambda(e_i^0)_{i=1}^m$ . 此时,  $\hat{\mathcal{R}}_{S^\lambda}(\Phi_\theta)$  在  $\theta$  处的 Hessian 矩阵为  $\mathbf{H}^\lambda(\theta)$ , 且满足

$$\mathbf{H}^\lambda(\theta) = \mathbf{H}_0^0(\theta) + \lambda \mathbf{H}_1^0(\theta).$$

因此, 当  $\lambda$  很大时,  $\mathbf{H}^\lambda(\theta)$  是  $\mathbf{H}_1^0(\theta)$  的放大版本的一个扰动. 显然, 若  $\mathbf{v}$  是  $\mathbf{H}_1(\theta)$  的特征向量, 对应负特征值  $-\mu$ , 则

$$\mathbf{v}^\top \mathbf{H}^\lambda(\theta) \mathbf{v} \leq (\|\mathbf{H}_0^0(\theta)\| - \lambda\mu) \|\mathbf{v}\|^2,$$

可以预期, 当  $\lambda$  很大时右端为负. 因而, 当  $\lambda$  很大时,  $\mathbf{H}^\lambda(\theta)$  有负特征值.

另一方面, 当  $\lambda$  很小时,  $\mathbf{H}^\lambda(\theta)$  只是  $\mathbf{H}_0^0(\theta)$  的一个扰动, 可以预期其谱会越来越接近  $\mathbf{H}_0^0$  的谱.

由此可见, 对同一个参数而言, 使经验风险较高的样本比风险较小的样本更有可能令该参数成为鞍点. 注意, 因为只证明了  $\mathbf{H}_0^0(\theta)$  是半正定的, 所以上述论证即使在  $\lambda$  很小时也不能排除鞍点. 但它确实表明, 当  $\lambda$  很小时, 每个负特征值都会很小.

若要作更精细的分析, 在同一个样本下比较不同参数, 并量化局部极小值与鞍点各自出现的可能性, 就需要在权重上引入概率分布. 详情参见文献 [234].

## 文献与延伸阅读

损失景观可视化方面的结果受到文献 [182, 112, 143] 的启发. 关于伪谷不存在性的结果可见文献 [317], 文献 [251] 给出了类似结果. 文献 [63] 通过把损失景观与所谓的自旋玻璃模型联系起来对其进行研究, 并发现在强假设下, 与较低损失相联系的临界点比鞍点更可能是极小值. 文献 [234] 使用随机矩阵理论给出类似结果, 并超出了第 12.3 节所建立的结论. 关于鞍点, 文献 [73] 指出鞍点的存在比局部极小值的存在更成问题, 并引入了一种能够感知鞍点的替代优化算法.

与损失景观相关而本章尚未讨论的两个重要主题, 是模式连通性和极小值的尖锐性. 粗略地说, 模式连通性描述如下现象: 通过 SGD 在深度神经网络上找到的局部极小值, 往往可由损失同样低的简单曲线连接 [99, 84]. 此外, 极小值的尖锐性也已得到分析, 并与神经网络的泛化能力联系起来; 其思想是, 宽极小值更容易找到, 并且还会产生鲁棒的神经网络 [132, 57, 151]. 然而, 这似乎并不妨碍尖锐极小值具有良好泛化能力 [83].






图 12.2: 一组损失景观. 左列为使用 ReLU 激活函数的神经网络, 右列为使用双曲正切激活函数的神经网络的损失景观. 所有神经网络的输入维数均为 5, 输出维数均为 1. 此外, 从上到下, 隐藏层宽度依次为 1000, 20, 10, 隐藏层数依次为 1, 4, 7.

## 习题

**12.6.** 根据定义 12.3, 证明可微函数的一个局部极小值包含在某个伪谷中.

**12.7.** 设参数  $\theta_1$  与全局极小值  $\theta_2$  之间存在连续路径  $\alpha$ , 且  $\Lambda_{\mathcal{A}, \sigma, S, \mathcal{L}}(\alpha)$  单调递减. 证明  $\theta_1$  不可能是伪谷中的元素.

**12.8.** 对一个简单架构, 找出伪谷的一个例子.

提示: 使用单神经元 ReLU 神经网络, 并注意: 对两个斜率一正一负的网络, 参数空间中连接二者的每条连续路径都必须经过一个对应于常值函数的参数.



## 神经网络空间的形状

正如上一章所见，神经网络的损失景观可能相当复杂，而且通常不是凸的。从某种意义上说，这是因为我们采用了从神经网络参数化出发的映射视角。考虑一个凸损失函数  $\mathcal{L}: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$  和样本  $S = (\mathbf{x}_i, y_i)_{i=1}^m \in (\mathbb{R}^d \times \mathbb{R})^m$ 。

那么，对于两个神经网络  $\Phi_1, \Phi_2$  以及  $\alpha \in (0, 1)$ ，有

$$\begin{aligned}\widehat{\mathcal{R}}_S(\alpha\Phi_1 + (1-\alpha)\Phi_2) &= \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\alpha\Phi_1(\mathbf{x}_i) + (1-\alpha)\Phi_2(\mathbf{x}_i), y_i) \\ &\leq \frac{1}{m} \sum_{i=1}^m \alpha \mathcal{L}(\Phi_1(\mathbf{x}_i), y_i) + (1-\alpha) \mathcal{L}(\Phi_2(\mathbf{x}_i), y_i) \\ &= \alpha \widehat{\mathcal{R}}_S(\Phi_1) + (1-\alpha) \widehat{\mathcal{R}}_S(\Phi_2).\end{aligned}$$

因此，当把经验风险视为依赖于神经网络函数而非神经网络参数的映射时，它是凸的。凸函数没有伪极小值或鞍点。因而，如果从神经网络集合的视角出发，上一章中的问题便可避免。

那么，我们为何不在神经网络集合上而是在参数上进行优化？为了理解这一点，现在把与固定架构相联系的神经网络集合视为其他函数空间的子集，并对它进行研究。

我们从定义 12.1 中引入的实现映射  $R_\sigma$  开始。具体而言，我们将在第 13.1 节证明：若  $\sigma$  是 Lipschitz 连续的，则神经网络集合是  $\mathcal{PN}(\mathcal{A}, \infty)$  在一个局部 Lipschitz 映射下的像。第 13.2 节将利用这一事实证明，神经网络集合通常不是凸的，甚至具有任意大的孔洞。最后，第 13.3 节研究神经网络集合中在何种程度上存在对任意函数的最佳逼近。我们将说明，最佳逼近的缺失会导致神经网络的权重在训练过程中无限增长。

### 13.1 Lipschitz 参数化

本节研究实现映射  $R_\sigma$  的 Lipschitz 连续性。主要结果是文献 [235, 命题 4] 的如下简化版本。为陈述该结果，我们引入一个由零和一组成的稀疏向量  $\mathbf{s}$ 。其作用是通过网络权重  $\mathbf{w}$  与稀疏向量  $\mathbf{s}$  的逐元素乘法，关闭网络的某些参数。这使我们能够联系第 5–7 章中构造的（稀疏）网络，以证明收敛率。

回顾架构  $\mathcal{A} = (d_0, \dots, d_{L+1})$ ，全连接网络的参数个数为

$$n_{\mathcal{A}} = \sum_{\ell=0}^L d_{\ell+1}(d_{\ell} + 1).$$

下文再次使用参数范围  $\mathcal{PN}(\mathcal{A}, B)$  的记号，并将实现映射写为

$$R_\sigma: \mathbf{w} \mapsto \Phi(\cdot, \mathbf{w}),$$

其中  $\mathbf{w} \in \mathbb{R}^{n_{\mathcal{A}}}$ （参见定义 2.1 和定义 12.1）。

**命题 13.1:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是  $C_\sigma$ -Lipschitz 连续的, 其中  $C_\sigma \geq 1$ ; 设对所有  $x \in \mathbb{R}$  都有  $|\sigma(x)| \leq C_\sigma(1 + |x|)$ , 且  $B \geq 1$ .

设  $\mathbf{s} \in \{0, 1\}^{n_A}$ . 则对所有  $\mathbf{w}, \mathbf{v} \in \mathcal{PN}(\mathcal{A}, B)$ ,

$$\|R_\sigma(\mathbf{w} \odot \mathbf{s}) - R_\sigma(\mathbf{v} \odot \mathbf{s})\|_{L^\infty([-1, 1]^{d_0})} \leq (3C_\sigma B d_{\max})^L |\mathbf{s}| \|\mathbf{w} - \mathbf{v}\|_\infty,$$

其中  $d_{\max} = \max_{\ell=0, \dots, L+1} d_\ell$ , 且  $|\mathbf{s}| = \sum_{j=1}^{n_A} s_j \leq n_A$ .

在证明命题 13.1 之前, 我们先给出两个引理, 分别研究前馈神经网络的 Lipschitz 性质以及各层输出的上界.

**引理 13.2:** 设  $\mathcal{A} = (d_0, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是  $C_\sigma$ -Lipschitz 连续的, 其中  $C_\sigma \geq 0$ , 并设  $B \geq 0$ . 则对所有  $\Phi \in \mathcal{N}(\sigma; \mathcal{A}, B)$  以及所有  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^{d_0}$ , 有

$$\|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_\infty \leq C_\sigma^L (B d_{\max})^{L+1} \|\mathbf{x} - \mathbf{y}\|_\infty. \quad (13.1.1)$$

**证明:** 先考虑  $L = 1$  的情形. 此时, 对  $\mathcal{A} = (d_0, d_1, d_2)$ , 有

$$\Phi(\mathbf{x}) = \mathbf{W}^{(1)} \sigma(\mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}) + \mathbf{b}^{(1)},$$

其中某些  $\mathbf{W}^{(0)}, \mathbf{W}^{(1)}, \mathbf{b}^{(0)}, \mathbf{b}^{(1)}$  的所有分量绝对值都不超过  $B$ . 因此

$$\begin{aligned} \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_\infty &= \|\mathbf{W}^{(1)} (\sigma(\mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}) - \sigma(\mathbf{W}^{(0)} \mathbf{y} + \mathbf{b}^{(0)}))\|_\infty \\ &\leq d_1 B \|\sigma(\mathbf{W}^{(0)} \mathbf{x} + \mathbf{b}^{(0)}) - \sigma(\mathbf{W}^{(0)} \mathbf{y} + \mathbf{b}^{(0)})\|_\infty \\ &\leq d_1 B C_\sigma \|\mathbf{W}^{(0)} (\mathbf{x} - \mathbf{y})\|_\infty \\ &\leq d_1 d_0 B^2 C_\sigma \|\mathbf{x} - \mathbf{y}\|_\infty \\ &\leq C_\sigma (d_{\max} B)^2 \|\mathbf{x} - \mathbf{y}\|_\infty, \end{aligned}$$

这里使用了  $\sigma$  的 Lipschitz 连续性, 以及对每个矩阵  $\mathbf{A} = (A_{ij})_{i=1, j=1}^{m, n} \in \mathbb{R}^{m \times n}$  都成立的估计  $\|\mathbf{A} \mathbf{z}\|_\infty \leq n \max_{i,j} |A_{ij}| \|\mathbf{z}\|_\infty$ .

从  $L$  到  $L+1$  的归纳步骤与此类似. 引理得证.  $\square$

在下一个引理中,  $\mathbf{x}^{(\ell)}$  与式 (2.1) 中一样, 表示第  $\ell$  层的输出.

**引理 13.3:** 考虑命题 13.1 的设定. 则

$$\|\mathbf{x}^{(\ell)}\|_\infty \leq (3C_\sigma B d_{\max})^\ell \quad \text{对所有 } \mathbf{x} \in [-1, 1]^{d_0}. \quad (13.1.2)$$

**证明:** 显然, 只需考虑  $\mathbf{s} = (1)_{j=1}^{n_A}$  的情形; 这允许绝对值不超过  $B$  的任意权重 (特别包括零权重).

由定义式 (2.1b) 和 (2.1c), 对  $\ell = 1, \dots, L+1$  有

$$\begin{aligned} \|\mathbf{x}^{(\ell)}\|_\infty &\leq C_\sigma \|\mathbf{W}^{(\ell-1)} \mathbf{x}^{(\ell-1)} + \mathbf{b}^{(\ell-1)}\|_\infty + C_\sigma \\ &\leq C_\sigma B d_{\max} \|\mathbf{x}^{(\ell-1)}\|_\infty + B C_\sigma + C_\sigma, \end{aligned}$$

这里使用了  $|\sigma(y)| \leq C_\sigma(1 + |y|)$ 、三角不等式, 以及估计  $\|\mathbf{A} \mathbf{x}\|_\infty \leq n \max_{i,j} |A_{ij}| \|\mathbf{x}\|_\infty$ . 由于  $B, d_{\max} \geq 1$ , 从而

$$\|\mathbf{x}^{(\ell)}\|_\infty \leq 3C_\sigma B d_{\max} \max\{1, \|\mathbf{x}^{(\ell-1)}\|_\infty\}.$$

以  $2C_\sigma Bd_{\max}(\max\{1, \|\mathbf{x}^{(\ell-1)}\|_\infty\})$  展开  $\|\mathbf{x}^{(\ell)}\|_\infty$  的递推估计, 可得

$$\|\mathbf{x}^{(\ell)}\|_\infty \leq (3C_\sigma Bd_{\max})^\ell \max\{1, \|\mathbf{x}^{(0)}\|_\infty\} = (3C_\sigma Bd_{\max})^\ell.$$

引理得证. □

现在可以证明该命题.

**命题 13.1 的证明:** 设  $\mathbf{w}, \mathbf{v} \in \mathcal{PN}(\mathcal{A}, B)$ . 不失一般性, 假定  $\mathbf{s} = (1, \dots, 1, 0, \dots, 0)$ , 即  $\mathbf{s}$  的前  $s := |\mathbf{s}|$  个分量为 1.

对  $j = 0, \dots, s-1$ , 令

$$\mathbf{u}_j := (w_1, \dots, w_{n_{\mathcal{A}}-j}, v_{n_{\mathcal{A}}-j+1}, \dots, v_{n_{\mathcal{A}}})^\top,$$

于是  $\mathbf{u}_j$  与  $\mathbf{u}_{j+1}$  仅有一个分量不同, 特别地,  $\mathbf{u}_0 \odot \mathbf{s} = \mathbf{w} \odot \mathbf{s}$  且  $\mathbf{u}_s \odot \mathbf{s} = \mathbf{v} \odot \mathbf{s}$ . 对任意  $\mathbf{x} \in [-1, 1]^{d_0}$ , 三角不等式给出

$$\|R_\sigma(\mathbf{w})(\mathbf{x}) - R_\sigma(\mathbf{v})(\mathbf{x})\|_\infty \leq \sum_{j=0}^{s-1} \|R_\sigma(\mathbf{u}_j)(\mathbf{x}) - R_\sigma(\mathbf{u}_{j+1})(\mathbf{x})\|_\infty. \quad (13.1.3)$$

固定  $j \in \{0, \dots, s-1\}$ , 并设  $\mathbf{u}_j$  与  $\mathbf{u}_{j+1}$  的不同分量属于第  $\ell$  层的一个参数. 先假设  $\ell < L$ . 则对  $\mathbf{x} \in [-1, 1]^{d_0}$ ,

$$|R_\sigma(\mathbf{u}_j)(\mathbf{x}) - R_\sigma(\mathbf{u}_{j+1})(\mathbf{x})| = |\Phi^\ell(\sigma(\mathbf{W}^{(\ell)}\mathbf{x}^{(\ell)} + \mathbf{b}^{(\ell)})) - \Phi^\ell(\sigma(\overline{\mathbf{W}}^{(\ell)}\mathbf{x}^{(\ell)} + \overline{\mathbf{b}}^{(\ell)}))|,$$

其中  $\Phi_\ell \in \mathcal{N}(\sigma; \mathcal{A}_\ell, B)$ ,  $\mathcal{A}_\ell = (d_{\ell+1}, \dots, d_{L+1})$ , 且  $(\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})$  与  $(\overline{\mathbf{W}}^{(\ell)}, \overline{\mathbf{b}}^{(\ell)})$  仅有一个分量不同.

利用引理 13.2 中  $\Phi_\ell$  的 Lipschitz 连续性, 得到

$$\begin{aligned} & |R_\sigma(\mathbf{u}_j)(\mathbf{x}) - R_\sigma(\mathbf{u}_{j+1})(\mathbf{x})| \\ & \leq C_\sigma^{L-\ell-1} (Bd_{\max})^{L-\ell} |\sigma(\mathbf{W}^{(\ell)}\mathbf{x}^{(\ell)} + \mathbf{b}^{(\ell)}) - \sigma(\overline{\mathbf{W}}^{(\ell)}\mathbf{x}^{(\ell)} + \overline{\mathbf{b}}^{(\ell)})| \\ & \leq C_\sigma^{L-\ell} (Bd_{\max})^{L-\ell} \|\mathbf{W}^{(\ell)}\mathbf{x}^{(\ell)} + \mathbf{b}^{(\ell)} - \overline{\mathbf{W}}^{(\ell)}\mathbf{x}^{(\ell)} - \overline{\mathbf{b}}^{(\ell)}\|_\infty \\ & \leq 2C_\sigma^{L-\ell} (Bd_{\max})^{L-\ell} \|\mathbf{w} \odot \mathbf{s} - \mathbf{v} \odot \mathbf{s}\|_\infty \max\{1, \|\mathbf{x}^{(\ell)}\|_\infty\}. \end{aligned}$$

调用引理 13.3, 可得

$$\begin{aligned} |R_\sigma(\mathbf{u}_j)(\mathbf{x}) - R_\sigma(\mathbf{u}_{j+1})(\mathbf{x})| & \leq (3C_\sigma Bd_{\max})^\ell C_\sigma^{L-\ell} (Bd_{\max})^{L-\ell} \delta \\ & \leq (3C_\sigma Bd_{\max})^L \|\mathbf{w} \odot \mathbf{s} - \mathbf{v} \odot \mathbf{s}\|_\infty. \end{aligned}$$

对  $\ell = L$  的情形, 可以得到类似估计. 将其与式 (13.1.3) 结合即得结论. □

利用命题 13.1, 现在可以把固定架构的神经网络集合  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  视为  $L^\infty([-1, 1]^{d_0})$  的子集. 此外, 对于 (非稀疏) 情形  $\mathbf{s} = (1)_{j=1}^{n_{\mathcal{A}}}$ , 我们已经证明  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  是  $\mathcal{PN}(\mathcal{A}, \infty)$  在一个局部 Lipschitz 映射下的像.

## 13.2 神经网络空间的凸性

为了把  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  理解为  $L^\infty([-1, 1]^{d_0})$  的子集, 我们首先注意到它是一个中心很少的星形集. 先引入所需术语.

**定义 13.4:** 设  $Z$  是线性空间的一个子集. 若点  $x \in Z$  满足: 对每个  $y \in Z$  都有

$$\{tx + (1-t)y \mid t \in [0, 1]\} \subseteq Z,$$

则称  $x$  为  $Z$  的中心 (center). 若一个集合至少有一个中心, 则称它是星形的 (star-shaped).

下面的命题直接由神经网络的定义得到, 同时也是习题 13.15 的内容.

**命题 13.5:** 设  $L \in \mathbb{N}$ ,  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ , 且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 则  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  具有缩放不变性, 即对每个  $\lambda \in \mathbb{R}$ , 若  $f \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 则  $\lambda f \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ ; 因而  $0 \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$  是  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  的一个中心.

知道  $\mathcal{N}(\sigma; \mathcal{A}, B)$  是以 0 为中心的星形集后, 还可以问它是否有不止这一个中心. 不难看出, 每个常值函数也都是中心. 下述定理对应于文献 [235, 命题 C.4], 它给出了线性无关中心个数的上界.

**定理 13.6:** 设  $L \in \mathbb{N}$ ,  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ , 且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 Lipschitz 连续的. 则  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  至多包含

$$n_{\mathcal{A}} = \sum_{\ell=0}^L (d_{\ell} + 1) d_{\ell+1}$$

个线性无关的中心.

**证明:** 反设存在函数  $(g_i)_{i=1}^{n_{\mathcal{A}}+1} \subseteq \mathcal{N}(\sigma; \mathcal{A}, \infty) \subseteq L^\infty([-1, 1]^{d_0})$ , 它们线性无关且都是  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  的中心.

由 Hahn-Banach 定理, 存在

$$(g'_i)_{i=1}^{n_{\mathcal{A}}+1} \subseteq (L^\infty([-1, 1]^{d_0}))',$$

使得对所有  $i, j \in \{1, \dots, L+1\}$  都有  $g'_i(g_j) = \delta_{ij}$ . 定义

$$T: L^\infty([-1, 1]^{d_0}) \longrightarrow \mathbb{R}^{n_{\mathcal{A}}+1}, \quad g \longmapsto \begin{pmatrix} g'_1(g) \\ g'_2(g) \\ \vdots \\ g'_{n_{\mathcal{A}}+1}(g) \end{pmatrix}.$$

由于  $T$  连续且线性, 由命题 13.1,  $T \circ R_\sigma$  局部 Lipschitz 连续. 此外, 由于  $(g_i)_{i=1}^{n_{\mathcal{A}}+1}$  线性无关,

$$T(\text{span}((g_i)_{i=1}^{n_{\mathcal{A}}+1})) = \mathbb{R}^{n_{\mathcal{A}}+1}.$$

记  $V := \text{span}((g_i)_{i=1}^{n_{\mathcal{A}}+1})$ .

接下来证明  $\mathcal{N}(\sigma; \mathcal{A}, \infty) \supset V$ . 设  $g \in V$ , 则对某些  $a_1, \dots, a_{n_{\mathcal{A}}+1} \in \mathbb{R}$ , 有

$$g = \sum_{\ell=1}^{n_{\mathcal{A}}+1} a_{\ell} g_{\ell}.$$

我们用归纳法证明, 对每个  $m \leq n_{\mathcal{A}} + 1$ ,  $\tilde{g}^{(m)} := \sum_{\ell=1}^m a_{\ell} g_{\ell} \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ . 当  $m = 1$  时这显然成立. 此外,  $\tilde{g}^{(m+1)} = a_{m+1} g_{m+1} + \tilde{g}^{(m)}$ . 因此, 若  $a_{m+1} = 0$ , 归纳步骤成立. 若  $a_{m+1} \neq 0$ , 则

$$\tilde{g}^{(m+1)} = 2a_{m+1} \left( \frac{1}{2} g_{m+1} + \frac{1}{2a_{m+1}} \tilde{g}^{(m)} \right). \quad (13.2.1)$$

由归纳假设  $\tilde{g}^{(m)} \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 再由命题 13.5,  $\tilde{g}^{(m)}/a_{m+1} \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ . 又因为  $g_{m+1}$  是  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  的中心, 故

$$\frac{1}{2} g_{m+1} + \frac{1}{2a_{m+1}} \tilde{g}^{(m)} \in \mathcal{N}(\sigma; \mathcal{A}, \infty).$$

再次应用命题 13.5, 得到  $\tilde{g}^{(m+1)} \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ .

归纳表明  $g \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 因而  $V \subseteq \mathcal{N}(\sigma; \mathcal{A}, \infty)$ . 所以

$$T \circ R_{\sigma}(\mathcal{PN}(\mathcal{A}, \infty)) \supseteq T(V) = \mathbb{R}^{n_{\mathcal{A}}+1}.$$

基础分析中一个熟知的事实是: 对每个  $n \in \mathbb{N}$ , 不存在从  $\mathbb{R}^n$  到  $\mathbb{R}^{n+1}$  的满射局部 Lipschitz 连续映射. 回顾  $n_{\mathcal{A}} = \dim(\mathcal{PN}(\mathcal{A}, \infty))$ . 这就产生了矛盾.  $\square$

对于凸集  $X$ ,  $X$  中任意两点之间的线段都是  $X$  的子集. 因此, 凸集的每一点都是中心. 由此得到下述推论.

**推论 13.7:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1})$ , 设, 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 Lipschitz 连续的. 若  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  包含多于

$$n_{\mathcal{A}} = \sum_{\ell=0}^L (d_{\ell} + 1) d_{\ell+1}$$

个线性无关函数, 则  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  不是凸的.

推论 13.7 表明, 若神经网络集合含有许多线性无关元素, 就不能期望它是凸集. 对每个  $f \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 神经网络集合也包含该函数的所有平移, 即对  $\mathbf{b} \in \mathbb{R}^d$ ,  $f(\cdot + \mathbf{b})$  也是  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  的元素. 对一个函数集合而言, 同时具有平移不变性且只含有限多个线性无关函数, 是一个非常严格的条件. 事实上, 文献 [235, 命题 C.6] 已经证明: 若  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  只含有限多个线性无关函数, 且  $\sigma$  至少在一点可微并且在该点导数非零, 则  $\sigma$  必为多项式.

综上, 神经网络集合一般不是凸的, 而是以 0 和常值函数为中心的星形集. 可以像图 13.1 那样在三维空间中将它可视化.




图 13.1: 三维神经网络空间的示意图. 竖直轴对应于常值神经网络函数, 其中每一个都是中心. 神经网络集合由许多低维线性子空间组成, 这些子空间由某些神经网络 (本示意图中的  $\Phi_1, \dots, \Phi_6$ ) 和线性函数张成. 由推论 13.7 和定理 13.9, 这些低维子空间之间并不总是存在直线连接.

神经网络空间不是凸的这一事实, 也可能只意味着它在一个点处不满足凸性. 例如,  $\mathbb{R}^2 \setminus \{0\}$  不是凸集, 但这对优化算法而言很可能不构成问题.

下面将看到,  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  并不具有这种温和的非凸性; 事实上, 它具有任意大的孔洞.

为严格表述这一结论, 先引入  $\varepsilon$ -凸性的概念.

**定义 13.8:** 对  $\varepsilon > 0$ , 若赋范向量空间  $X$  的子集  $A$  满足

$$\text{co}(A) \subseteq A + B_\varepsilon(0),$$

其中  $\text{co}(A)$  表示  $A$  的凸包, 而  $B_\varepsilon(0)$  是在  $X$  的范数下以  $0$  为中心的  $\varepsilon$ -球, 则称  $A$  是  $\varepsilon$ -凸的 (epsilon-convex).

直观地说, 若把所有小于  $\varepsilon$  的孔洞填满后一个集合成为凸集, 则它是  $\varepsilon$ -凸的. 现在证明, 不存在  $\varepsilon > 0$  使  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  为  $\varepsilon$ -凸的.

**定理 13.9:** 设  $L \in \mathbb{N}$ ,  $\mathcal{A} = (d_0, d_1, \dots, d_L, 1) \in \mathbb{N}^{L+2}$ . 设  $K \subseteq \mathbb{R}^{d_0}$  为紧集,  $\sigma \in \mathcal{M}$ , 其中  $\mathcal{M}$  如式 (3.1) 所定义, 并假设  $\sigma$  不是多项式. 此外, 假设存在一个开集, 使得  $\sigma$  在其上可微且不是常值函数.

若存在  $\varepsilon > 0$  使  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  为  $\varepsilon$ -凸的, 则  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  在  $C(K)$  中稠密.

**证明:** 步骤 1. 证明  $\varepsilon$ -凸性蕴含  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  是凸的. 由命题 13.5,  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  具有缩放不变性. 这意味着  $\text{co}(\mathcal{N}(\sigma; \mathcal{A}, \infty))$  也具有缩放不变性. 因此, 若存在  $\varepsilon > 0$  使

$\mathcal{N}(\sigma; \mathcal{A}, \infty)$  为  $\varepsilon$ -凸的, 则对每个  $\varepsilon' > 0$ ,

$$\begin{aligned} \text{co}(\mathcal{N}(\sigma; \mathcal{A}, \infty)) &= \frac{\varepsilon'}{\varepsilon} \text{co}(\mathcal{N}(\sigma; \mathcal{A}, \infty)) \\ &\subseteq \frac{\varepsilon'}{\varepsilon} (\mathcal{N}(\sigma; \mathcal{A}, \infty) + B_\varepsilon(0)) \\ &= \mathcal{N}(\sigma; \mathcal{A}, \infty) + B_{\varepsilon'}(0). \end{aligned}$$

这表明  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  是  $\varepsilon'$ -凸的. 由于  $\varepsilon'$  任意,  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  对所有  $\varepsilon > 0$  都是  $\varepsilon$ -凸的. 因此,

$$\begin{aligned} \text{co}(\mathcal{N}(\sigma; \mathcal{A}, \infty)) &\subseteq \bigcap_{\varepsilon > 0} (\mathcal{N}(\sigma; \mathcal{A}, \infty) + B_\varepsilon(0)) \\ &\subseteq \overline{\bigcap_{\varepsilon > 0} (\mathcal{N}(\sigma; \mathcal{A}, \infty) + B_\varepsilon(0))} = \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}. \end{aligned}$$

故  $\overline{\text{co}(\mathcal{N}(\sigma; \mathcal{A}, \infty))} \subseteq \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$ . 再利用每个度量向量空间中的熟知事实  $\text{co}(\overline{A}) \subseteq \overline{\text{co}(A)}$ , 可知  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  是凸的.

**步骤 2.** 证明  $\mathcal{N}_d^1(\sigma; 1) \subseteq \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$ . 若  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  是  $\varepsilon$ -凸的, 则由步骤 1,  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  是凸的. 再由  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  的缩放不变性,  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  是  $C(K)$  的闭线性子空间.

注意, 由命题 3.17, 对每个  $\mathbf{w} \in \mathbb{R}^{d_0}$  和  $b \in \mathbb{R}$ , 都存在  $f \in \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$ , 使得

$$f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) \quad \text{对所有 } \mathbf{x} \in K. \quad (13.2.2)$$

由定义, 每个常值函数都是  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  的元素.

由于  $\overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$  是闭向量空间, 这意味着对所有  $n \in \mathbb{N}$ , 以及所有  $\mathbf{w}_1^{(1)}, \dots, \mathbf{w}_n^{(1)} \in \mathbb{R}^{d_0}$ ,  $w_1^{(2)}, \dots, w_n^{(2)} \in \mathbb{R}$ ,  $b_1^{(1)}, \dots, b_n^{(1)} \in \mathbb{R}$ ,  $b^{(2)} \in \mathbb{R}$ , 都有

$$\mathbf{x} \mapsto \sum_{i=1}^n w_i^{(2)} \sigma((\mathbf{w}_i^{(1)})^\top \mathbf{x} + b_i^{(1)}) + b^{(2)} \in \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}. \quad (13.2.3)$$

**步骤 3.** 由式 (13.2.3), 可得  $\mathcal{N}_d^1(\sigma; 1) \subseteq \overline{\mathcal{N}(\sigma; \mathcal{A}, \infty)}$ . 换言之, 任意宽度的浅层神经网络全集包含于固定架构神经网络集合的闭包中. 由定理 3.9,  $\mathcal{N}_d^1(\sigma; 1)$  在  $C(K)$  中稠密, 结论随即成立.  $\square$

对任何具有实际意义的激活函数, 固定架构神经网络集合都不在  $C(K)$  中稠密. 只有第 3.2 节讨论的那类非常奇特的激活函数才会出现这种情形. 因而, 定理 13.9 表明, 一般而言, 固定架构的神经网络集合具有任意大的孔洞.

### 13.3 闭性与最佳逼近性质

神经网络集合的非凸性, 会对我们思考神经网络逼近问题或学习问题的方式产生一些严重后果.



考虑  $\mathcal{A} = (d_0, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$  和激活函数  $\sigma$ . 设  $H$  是  $[-1, 1]^{d_0}$  上的赋范函数空间, 且  $\mathcal{N}(\sigma; \mathcal{A}, \infty) \subseteq H$ . 对  $h \in H$ , 我们希望找到一个最佳逼近  $h$  的神经网络, 即找到  $\Phi_* \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 使得

$$\|\Phi_* - h\|_H = \inf_{\Phi \in \mathcal{N}(\sigma; \mathcal{A}, \infty)} \|\Phi - h\|_H. \quad (13.3.1)$$

称  $\mathcal{N}(\sigma; \mathcal{A}, \infty) \subseteq H$  具有

- 最佳逼近性质 (best approximation property), 若对所有  $h \in H$ , 至少存在一个  $\Phi_* \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$  使式 (13.3.1) 成立;
- 唯一最佳逼近性质 (unique best approximation property), 若对所有  $h \in H$ , 恰好存在一个  $\Phi_* \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$  使式 (13.3.1) 成立;
- 连续选取性质 (continuous selection property), 若存在连续函数

$$\phi: H \rightarrow \mathcal{N}(\sigma; \mathcal{A}, \infty),$$

使得对所有  $h \in H$ ,  $\Phi_* = \phi(h)$  都满足式 (13.3.1).

下文将看到, 若最佳逼近性质不成立, 则可以证明学习问题必然要求神经网络的权重趋于无穷; 这在应用中可能合意, 也可能不合意.

此外, 具有连续选取过程是合意的, 因为它蕴含稳定选取算法的存在; 也就是说, 该算法对相近的问题会给出满足式 (13.3.1) 的相近神经网络.

下面将对  $L^p$  空间 ( $p \in [1, \infty)$ ) 研究上述性质. 我们将看到, 神经网络类通常既不满足连续选取性质, 也不满足最佳逼近性质.

### 13.3.1 连续选取

文献 [153] 表明, 神经网络空间基本上从不具有连续选取性质. 为说明这一论证, 先不加证明地回顾文献 [153, 定理 3.4] 中的下述结果.

**定理 13.10:** 设  $p \in (1, \infty)$ .  $L^p([-1, 1]^{d_0})$  中每个具有唯一最佳逼近性质的子集都是凸的.

由此可以证明下面的命题.

**命题 13.11:** 设  $L \in \mathbb{N}$ ,  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 Lipschitz 连续的且不是多项式, 并设  $p \in (1, \infty)$ .

则  $\mathcal{N}(\sigma; \mathcal{A}, \infty) \subseteq L^p([-1, 1]^{d_0})$  不具有连续选取性质.

**证明:** 由定理 13.6 及其后的讨论可知, 在当前假设下,  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  不是凸的.

由定理 13.10,  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  不具有唯一最佳逼近性质. 此外, 若集合  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  不具有最佳逼近性质, 则显然不可能具有连续选取. 因此不失一般性, 可以假设  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  具有最佳逼近性质, 并且存在一点  $h \in L^p([-1, 1]^{d_0})$  以及两个不同的  $\Phi_1, \Phi_2$ , 使得

$$\|\Phi_1 - h\|_{L^p} = \|\Phi_2 - h\|_{L^p} = \inf_{\Phi \in \mathcal{N}(\sigma; \mathcal{A}, \infty)} \|\Phi - h\|_{L^p}. \quad (13.3.2)$$

注意, 式 (13.3.2) 蕴含  $h \notin \mathcal{N}(\sigma; \mathcal{A}, \infty)$ .

考虑如下函数:

$$[-1, 1] \ni \lambda \mapsto P(\lambda) = \begin{cases} (1 + \lambda)h - \lambda\Phi_1, & \lambda \leq 0, \\ (1 - \lambda)h + \lambda\Phi_2, & \lambda \geq 0. \end{cases}$$

显然,  $P(\lambda)$  是  $L^p$  中的一条连续路径. 此外, 对  $\lambda \in (-1, 0)$ ,

$$\|\Phi_1 - P(\lambda)\|_{L^p} = (1 + \lambda)\|\Phi_1 - h\|_{L^p}.$$

反设存在  $\Phi_* \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$ ,  $\Phi_* \neq \Phi_1$ , 使得对  $\lambda \in (-1, 0)$ ,

$$\|\Phi_* - P(\lambda)\|_{L^p} \leq \|\Phi_1 - P(\lambda)\|_{L^p}.$$

于是

$$\begin{aligned} \|\Phi_* - h\|_{L^p} &\leq \|\Phi_* - P(\lambda)\|_{L^p} + \|P(\lambda) - h\|_{L^p} \\ &\leq \|\Phi_1 - P(\lambda)\|_{L^p} + \|P(\lambda) - h\|_{L^p} \\ &= (1 + \lambda)\|\Phi_1 - h\|_{L^p} + |\lambda|\|\Phi_1 - h\|_{L^p} = \|\Phi_1 - h\|_{L^p}. \end{aligned} \quad (13.3.3)$$

由于  $\Phi_1$  是  $h$  的一个最佳逼近, 上述估计中的每个不等式都必须取等号. 因而

$$\|\Phi_* - h\|_{L^p} = \|\Phi_* - P(\lambda)\|_{L^p} + \|P(\lambda) - h\|_{L^p}.$$

然而, 当  $p > 1$  时,  $L^p([-1, 1]^{d_0})$  是严格凸空间, 所以存在常数  $c \neq 0$ , 使得

$$\Phi_* - P(\lambda) = c(P(\lambda) - h).$$

这给出

$$\Phi_* = h + (c + 1)\lambda(h - \Phi_1).$$

代入式 (13.3.3) 得  $|(c + 1)\lambda| = 1$ . 若  $(c + 1)\lambda = -1$ , 则  $\Phi_* = \Phi_1$ , 产生矛盾. 若  $(c + 1)\lambda = 1$ , 则

$$\begin{aligned} \|\Phi_* - P(\lambda)\|_{L^p} &= \|2h - \Phi_1 - (1 + \lambda)h + \lambda\Phi_1\|_{L^p} \\ &= \|(1 - \lambda)h - (1 - \lambda)\Phi_1\|_{L^p} > \|P(\lambda) - \Phi_1\|_{L^p}, \end{aligned}$$

这又是一个矛盾.

因此, 对每个  $\lambda < 0$ ,  $\Phi_1$  都是  $P(\lambda)$  在  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  中的唯一极小化子. 对  $\lambda > 0$  和  $\Phi_2$ , 同样的论证成立. 于是, 对每个选取函数  $\phi: L^p([-1, 1]^{d_0}) \rightarrow \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 若  $\Phi = \phi(h)$  对所有  $h \in L^p([-1, 1]^{d_0})$  都满足式 (13.3.1), 则

$$\lim_{\lambda \downarrow 0} \phi(P(\lambda)) = \Phi_2 \neq \Phi_1 = \lim_{\lambda \uparrow 0} \phi(P(\lambda)).$$

因此,  $\phi$  不连续, 结论得证. □

### 13.3.2 最佳逼近的存在性

我们已经在命题 13.11 中看到, 在非常温和的假设下, 连续选取性质不可能成立. 此外, 下面的结果表明, 在许多情形中, 最佳逼近性质也不成立. 这里给出 [235, 定理 3.1] 的一个简化版本. 关于这一问题的早期工作, 另见 [105].

**命题 13.12:** 设  $\mathcal{A} = (1, 2, 1)$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 Lipschitz 连续的. 进一步假设存在  $r > 0$  和  $\alpha' \neq \alpha$ , 使得  $\sigma$  对所有  $|x| > r$  可微, 并且当  $x \rightarrow \infty$  时  $\sigma'(x) \rightarrow \alpha$ , 当  $x \rightarrow -\infty$  时  $\sigma'(x) \rightarrow \alpha'$ .

则存在  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  中的一个序列, 它对每个  $p \in (1, \infty)$  都在  $L^p([-1, 1])$  中收敛, 而其极限是不连续的. 特别地, 该序列的极限不属于任意  $\mathcal{A}'$  所对应的  $\mathcal{N}(\sigma; \mathcal{A}', \infty)$ .

**证明:** 对所有  $n \in \mathbb{N}$ , 令

$$f_n(x) = \sigma(nx + 1) - \sigma(nx) \quad \text{对所有 } x \in \mathbb{R}.$$

则  $f_n$  可以写成架构为  $(\sigma; 1, 2, 1)$  的神经网络, 即  $\mathcal{A} = (1, 2, 1)$ . 此外, 对  $x > 0$ , 由微积分基本定理并作积分变量代换可得

$$f_n(x) = \int_x^{x+1/n} n\sigma'(nz) dz = \int_{nx}^{nx+1} \sigma'(z) dz. \quad (13.3.4)$$

不难看出, 当  $n \rightarrow \infty$  时, 式 (13.3.4) 的右端收敛到  $\alpha$ .

类似地, 对  $x < 0$ , 当  $n \rightarrow \infty$  时  $f_n(x)$  收敛到  $\alpha'$ . 因此, 当  $n \rightarrow \infty$  时,

$$f_n \rightarrow \alpha \mathbf{1}_{\mathbb{R}_+} + \alpha' \mathbf{1}_{\mathbb{R}_-}$$

几乎处处成立. 由于  $\sigma$  是 Lipschitz 连续的,  $f_n$  一致有界. 因而由控制收敛定理, 对所有  $p \in [1, \infty)$ ,  $f_n \rightarrow \alpha \mathbf{1}_{\mathbb{R}_+} + \alpha' \mathbf{1}_{\mathbb{R}_-}$  在  $L^p$  中成立.  $\square$

命题 13.12 可以直接推广到任意架构, 这将是习题 13.16 和习题 13.17 的内容.

**注 13.13:** 定理 13.12 的证明不能推广到  $L^\infty$  范数. 当然, 这并不意味着一般而言  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  是  $L^\infty([-1, 1]^{d_0})$  中的闭集. 事实上, 实践中使用的几乎所有激活函数仍然会产生非闭的神经网络集合, 见 [235, 定理 3.3]. 不过, 有一个值得注意的例外. 对 ReLU 激活函数, 可以证明: 若  $\mathcal{A}$  只有一个隐藏层, 则  $\mathcal{N}(\sigma_{\text{ReLU}}; \mathcal{A}, \infty)$  是  $L^\infty([-1, 1]^{d_0})$  中的闭集. 深层 ReLU 空间在  $L^\infty$  中的闭性仍是一个公开问题.  $\diamond$

### 13.3.3 权重爆炸现象

最后, 讨论命题 13.12 中最佳逼近不存在所导致的一个后果.

考虑一个回归问题, 其中我们希望用固定架构的神经网络  $\mathcal{N}(\mathcal{A}; \sigma, \infty)$  学习函数  $f$ . 正如第 10 章和第 11 章所讨论的, 我们希望构造一个神经网络序列  $(\Phi_n)_{n=1}^\infty$ , 使式 (1.4) 定义的风险收敛到 0. 若损失  $\mathcal{L}$  是平方损失,  $\mu$  是  $[-1, 1]^{d_0}$  上的概率测度, 并且数据为  $(\mathbf{x}, f(\mathbf{x}))$ , 其中  $\mathbf{x} \sim \mu$ , 则

$$\begin{aligned} \mathcal{R}(\Phi_n) &= \|\Phi_n - f\|_{L^2([-1, 1]^{d_0}, \mu)}^2 \\ &= \int_{[-1, 1]^{d_0}} |\Phi_n(\mathbf{x}) - f(\mathbf{x})|^2 d\mu(\mathbf{x}) \rightarrow 0 \quad \text{当 } n \rightarrow \infty. \end{aligned} \quad (13.3.5)$$

根据命题 13.12, 对给定的  $\mathcal{A}$  和激活函数  $\sigma$ , 可能有式 (13.3.5) 成立, 但  $f \notin \mathcal{N}(\sigma; \mathcal{A}, \infty)$ . 下面的结果表明, 在这种情形下,  $\Phi_n$  的权重会发散.

**命题 13.14:** 设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ , 设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是 Lipschitz 连续的,  $C_\sigma \geq 1$ , 且对所有  $x \in \mathbb{R}$  都有  $|\sigma(x)| \leq C_\sigma|x|$ ; 并设  $\mu$  是  $[-1, 1]^{d_0}$  上的一个测度.

假设存在序列  $\Phi_n \in \mathcal{N}(\sigma; \mathcal{A}, \infty)$  和函数  $f \in L^2([-1, 1]^{d_0}, \mu) \setminus \mathcal{N}(\sigma; \mathcal{A}, \infty)$ , 使得

$$\|\Phi_n - f\|_{L^2([-1, 1]^{d_0}, \mu)}^2 \rightarrow 0. \quad (13.3.6)$$

则

$$\limsup_{n \rightarrow \infty} \max \{ \|\mathbf{W}_n^{(\ell)}\|_\infty, \|\mathbf{b}_n^{(\ell)}\|_\infty \mid \ell = 0, \dots, L \} = \infty. \quad (13.3.7)$$

**证明:** 反设式 (13.3.7) 的左端是有限的. 因而存在  $C > 0$ , 使得对所有  $n \in \mathbb{N}$ , 都有  $\Phi_n \in \mathcal{N}(\sigma; \mathcal{A}, C)$ .

由命题 13.1,  $\mathcal{N}(\sigma; \mathcal{A}, C)$  是紧集在连续映射下的像, 因而其本身是  $L^2([-1, 1]^{d_0}, \mu)$  中的紧集. 特别地,  $\mathcal{N}(\sigma; \mathcal{A}, C)$  是闭的. 所以, 式 (13.3.6) 蕴含  $f \in \mathcal{N}(\sigma; \mathcal{A}, C)$ , 这产生矛盾.  $\square$

命题 13.14 可以推广到在  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  中不存在最佳逼近的所有  $f$ , 见习题 13.18. 上述结果意味着: 对于我们希望学习、但在某个神经网络集合中不存在最佳逼近的函数, 必须预期逼近神经网络的权重增长到无穷. 这可能是不利的, 因为正如后续关于泛化的各节将说明的, 有界参数空间有助于建立许多泛化界.

## 文献与延伸阅读

神经网络集合的性质最初是在连续逼近性质的背景下研究的, 见文献 [153, 155, 154] 和文献 [105]. 文献 [153, 154, 155] 中的结果已经利用了浅层神经网络集合的非凸性. 本章给出的凸性与闭性结果主要沿用文献 [235] 的论证. 文献 [192] 还对其他范数导出了类似结果.

## 习题

- 13.15. 证明命题 13.5.
- 13.16. 将命题 13.12 推广到  $\mathcal{A} = (d_0, d_1, 1)$ , 其中  $d_0, d_1 \in \mathbb{N}$  任意且  $d_1 \geq 2$ .
- 13.17. 利用命题 3.17, 将命题 13.12 推广到任意深度.
- 13.18. 将命题 13.14 推广到在  $\mathcal{N}(\sigma; \mathcal{A}, \infty)$  中不存在最佳逼近的函数  $f$ . 为此, 将式 (13.3.6) 替换为

$$\|\Phi_n - f\|_{L^2}^2 \rightarrow \inf_{\Phi \in \mathcal{N}(\sigma; \mathcal{A}, \infty)} \|\Phi - f\|_{L^2}^2.$$

## 深度神经网络的泛化性质


正如导论第 1.2 节所讨论的，我们通常基于有限数据集进行学习。例如，给定数据  $(x_i, y_i)_{i=1}^m$ ，我们试图找到一个网络  $\Phi$ ，使其对  $i = 1, \dots, m$ （近似）满足  $\Phi(x_i) = y_i$ 。泛化领域关注的是这样的  $\Phi$  在未见数据上的表现；未见数据是指训练数据  $\{x_1, \dots, x_m\}$  之外的任意  $x$ 。本章将利用覆盖数讨论泛化。

第 14.1 节和第 14.2 节将在一般背景下重新讨论并形式化学习与经验风险最小化的一般设定。尽管这两节引入的一些概念已在前面各章出现，为使论述更连贯，这里仍将重新引入它们。在第 14.3–14.5 节中，我们先讨论泛化界和覆盖数的概念，再把这些论证专门应用于神经网络。第 14.6 节将探讨所谓的逼近–复杂度权衡；最后，第 14.8–14.9 节将引入 VC 维，并给出它对神经网络类的一些推论。

### 14.1 学习设定

一般的学习问题 [202, 285, 71] 需要一个特征空间（feature space） $X$  和一个标签空间（label space） $Y$ ；本章始终假设二者都是可测空间。我们观测到联合数据对  $(x_i, y_i)_{i=1}^m \subseteq X \times Y$ ，并试图识别变量  $x$  与  $y$  之间的联系。具体而言，假设特征  $x$  与标签  $y$  之间的关系由  $X \times Y$  上的概率分布  $\mathcal{D}$  建模，观测数据  $(x_i, y_i)_{i=1}^m$  正是由它生成的。尽管该分布未知，我们的目标仍是从中提取信息，从而对给定的  $x$  尽可能良好地预测  $y$ 。重要的是， $x$  与  $y$  之间的关系不必是确定性的。

为了使这些概念更具体，下面给出一个例子，本章将用它解释各种思想。这个例子对许多数学家都极为重要，因为持续获得高品质咖啡，是最大化数学工作产出的关键。



| Acidity | Caffeine (mg/100ml) | Price | Aftertaste   | Roast level | Origin   | Quality |
|---------|---------------------|-------|--------------|-------------|----------|---------|
| 7/10    | 41                  | 5     | dry          | 8/10        | Ethiopia | 7/10    |
| 5/10    | 40                  | 7     | lingering    | 7/10        | Brazil   | 5/10    |
| 5/10    | 39                  | 6,5   | dry          | 7/10        | Columbia | 6/10    |
| 6/10    | 39,5                | 3     | sweet/floral | 5/10        | Vietnam  | 6/10    |
| 9/10    | 40                  | 9     | bitter       | 9/10        | Brazil   | 8/10    |
| 2/10    | 40,3                | 6,2   | bitter       | 8/10        | Ethiopia | 9/10    |
| 6/10    | 39,2                | 8     | fruity       | 7/10        | Brazil   | ???     |

图 14.1: 咖啡数据的收集。最后一行缺少“Quality”标签。我们的目标是在不进行（昂贵的）品尝测试的情况下预测该标签。

**例 14.1 (咖啡质量):** 我们的目标是确定不同咖啡的品质. 为此, 把品质建模为集合

$$Y = \left\{ \frac{0}{10}, \dots, \frac{10}{10} \right\}$$

中的一个数, 数值越高表示品质越好. 假设我们对咖啡品质的主观评价与六个特征有关: “Acidity”、“Caffeine content”、“Price”、“Aftertaste”、“Roast level” 和 “Origin”. 因而, 特征空间  $X$  对应于描述这些属性的六元组集合; 这些属性既可以是数值型的, 也可以是类别型的 (见图 14.1).

我们希望理解  $X$  中元素与  $Y$  中元素的关系, 但既负担不起、也没有时间品尝全世界所有的咖啡. 我们可以改为抽取一些咖啡, 品尝它们, 并像图 14.1 所示那样逐步扩充数据库. 这样便获得了  $X \times Y$  中的数据对样本. 它们所服从的分布  $\mathcal{D}$  取决于各种外部因素. 例如, 我们可能认为特别便宜的咖啡品质较差, 因而避免选择它们; 结果是数据库中不会出现这些咖啡. 此外, 若一位同事为数据库贡献数据, 他可能品尝了同一品牌, 却给出不同的评分. 在这种情况下, 品质标签便不再是确定性的.

根据数据库, 我们希望预测尚未品尝的咖啡的品质. 在继续之前, 先形式化何谓一个 “良好” 的预测.  $\diamond$

刻画一个预测器有多好, 需要在标签空间上定义偏差的概念. 这正是所谓损失函数的作用; 它是一个可测映射  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}_+$ .

**定义 14.2:** 设  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}_+$  是损失函数,  $\mathcal{D}$  是  $X \times Y$  上的一个分布. 对可测函数  $h: X \rightarrow Y$ , 称

$$\mathcal{R}(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{L}(h(x), y)]$$

为  $h$  的 (总体) 风险 ((population) risk).

借助风险, 现在可以形式化何谓良好的预测器. 最佳预测器的风险应尽可能接近任意函数所能达到的最小值. 更准确地说, 我们希望其风险接近所谓的 Bayes 风险 (Bayes risk)

$$R^* := \inf_{h: X \rightarrow Y} \mathcal{R}(h), \quad (14.1.1)$$

其中下确界取遍所有可测函数  $h: X \rightarrow Y$ .

**例 14.3 (损失函数):** 损失函数  $\mathcal{L}$  的选择通常取决于具体应用. 对回归问题, 即  $Y$  是欧几里得空间的非离散子集的学习问题, 一种常见选择是平方损失  $\mathcal{L}_2(\mathbf{y}, \mathbf{y}') = \|\mathbf{y} - \mathbf{y}'\|^2$ .

对二分类问题, 即  $Y$  是基数为二的离散集合时, “0-1 损失”

$$\mathcal{L}_{0-1}(y, y') = \begin{cases} 1, & y \neq y', \\ 0, & y = y' \end{cases}$$

显得更自然.

二分类 ( $Y = \{0, 1\}$ ) 中另一种常用损失是二元交叉熵损失 (binary cross-entropy loss), 特别是在假设返回概率时 (即  $h: X \rightarrow [0, 1]$ ):

$$\mathcal{L}_{\text{ce}}(y, y') = -(y \log(y') + (1 - y) \log(1 - y')).$$



与 0-1 损失不同，交叉熵损失是可微的；正如第 10 章所见，这一性质在深度学习上是合意的。

在咖啡品质预测问题中，品质由  $k/10$  形式的分数给出，其中  $k = 0, \dots, 10$ 。尽管这是一个离散集合，但对偏差更大的错误预测施加更重的惩罚是合理的。例如，把 8/10 预测为 4/10，应当比预测为 7/10 产生更高的损失。因此，我们不会使用 0-1 损失，而会使用例如平方损失。◇

怎样找到一个函数  $h: X \rightarrow Y$ ，使其风险尽可能接近 Bayes 风险？下一节将介绍一种处理这一任务的方法。

## 14.2 经验风险最小化

寻找风险的极小化子是一项相当困难的任务。首先，我们不可能遍历所有可测函数，因此需要把搜索限制在某个特定集合

$$\mathcal{H} \subseteq \{h: X \rightarrow Y \mid h \text{ 是可测的}\}$$

上，称之为假设集 (hypothesis set)。下文中，这个集合将是某个神经网络集合。其次，我们面临的问题是：对于非平凡损失函数，通常无法计算  $\mathcal{R}(h)$ ，因为分布  $\mathcal{D}$  一般未知，因而不能计算关于  $\mathcal{D}$  的期望。为了逼近风险，假设可以取得从  $\mathcal{D}$  中抽取的  $m$  个独立同分布观测所组成的样本。这正是图 14.1 的咖啡品质例所描述的情形，其中抽取了  $m = 6$  种咖啡。<sup>7</sup> 对给定的假设  $h$ ，我们可以据此检查它在样本数据上的表现。

**定义 14.4：** 设  $m \in \mathbb{N}$ ，设  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}$  是损失函数，并设  $S = (x_i, y_i)_{i=1}^m \in (X \times Y)^m$  是一个样本。对  $h: X \rightarrow Y$ ，称

$$\hat{\mathcal{R}}_S(h) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(h(x_i), y_i)$$

为  $h$  的经验风险。

若样本  $S$  按照  $\mathcal{D}$  独立同分布地抽取，则由期望的线性性立即可知， $\hat{\mathcal{R}}_S(h)$  是  $\mathcal{R}(h)$  的无偏估计量，即  $\mathbb{E}_{S \sim \mathcal{D}^m}[\hat{\mathcal{R}}_S(h)] = \mathcal{R}(h)$ 。此外，弱大数定律表明，可积独立同分布随机变量序列的样本均值依概率收敛到期望。因此至少对较大的  $m \in \mathbb{N}$ ，用极小化经验风险代替极小化总体风险，有希望得到一个良好的假设。下一个定义将这一方法形式化。

**定义 14.5：** 设  $\mathcal{H} \subseteq \{h: X \rightarrow Y\}$  是一个假设集。设  $m \in \mathbb{N}$ ，设  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}_+$  是损失函数，并设  $S = (x_i, y_i)_{i=1}^m \in (X \times Y)^m$  是一个样本。若函数  $h_S$  满足

$$\hat{\mathcal{R}}_S(h_S) = \inf_{h \in \mathcal{H}} \hat{\mathcal{R}}_S(h),$$

则称  $h_S$  为经验风险极小化子 (empirical risk minimizer)。

---

<sup>7</sup>在实践中，样本独立性的假设往往并不明确，而且通常不成立。例如，先前测试的六种咖啡可能受到个人偏好或当地商店供货情况等外部因素影响，从而在数据集中引入偏差。

从泛化的视角看，有监督深度学习是在神经网络集合上进行经验风险最小化。接下来要研究的问题是：这一方法在产生风险接近 Bayes 风险的假设方面究竟有多有效。

设  $\mathcal{H}$  是一个假设集，并且对所有  $S \in (X \times Y)^m$  都存在经验风险极小化子  $h_S$ ；关于这一假设为何合理，见习题 14.30。此外，任取  $g \in \mathcal{H}$ 。则

$$\begin{aligned} \mathcal{R}(h_S) - R^* &= \mathcal{R}(h_S) - \widehat{\mathcal{R}}_S(h_S) + \widehat{\mathcal{R}}_S(h_S) - R^* \\ &\leq |\mathcal{R}(h_S) - \widehat{\mathcal{R}}_S(h_S)| + \widehat{\mathcal{R}}_S(g) - R^* \\ &\leq 2 \sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| + \mathcal{R}(g) - R^*, \end{aligned} \quad (14.2.1)$$

其中第一个不等式使用了  $h_S$  是经验风险极小化子这一事实。对所有  $g$  取下确界，得到

$$\begin{aligned} \mathcal{R}(h_S) - R^* &\leq 2 \sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| + \inf_{g \in \mathcal{H}} \mathcal{R}(g) - R^* \\ &=: 2\varepsilon_{\text{gen}} + \varepsilon_{\text{approx}}. \end{aligned} \quad (14.2.2)$$

类似地，只考虑式 (14.2.1) 可得

$$\begin{aligned} \mathcal{R}(h_S) &\leq \sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| + \inf_{g \in \mathcal{H}} \widehat{\mathcal{R}}_S(g) \\ &=: \varepsilon_{\text{gen}} + \varepsilon_{\text{int}}. \end{aligned} \quad (14.2.3)$$

前面各章已经详细讨论了如何选择  $\mathcal{H}$ ，以减小逼近误差 (approximation error)  $\varepsilon_{\text{approx}}$  或插值误差 (interpolation error)  $\varepsilon_{\text{int}}$ 。最后还需要弄清怎样控制泛化误差  $\sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)|$ 。下面各节将对此进行讨论。

### 14.3 泛化界

我们已经看到，成功学习的一个方面是控制式 (14.2.2) 中的泛化误差  $\varepsilon_{\text{gen}}$ 。首先对这一问题作形式化描述。

**定义 14.6 (泛化界)：** 设  $\mathcal{H} \subseteq \{h: X \rightarrow Y\}$  是一个假设集， $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}_+$  是损失函数。设  $\kappa: (0, 1) \times \mathbb{N} \rightarrow \mathbb{R}_+$  满足：对每个  $\delta \in (0, 1)$ ，当  $m \rightarrow \infty$  时都有  $\kappa(\delta, m) \rightarrow 0$ 。若对  $X \times Y$  上的每个分布  $\mathcal{D}$ 、每个  $m \in \mathbb{N}$  和每个  $\delta \in (0, 1)$ ，关于随机样本  $S \sim \mathcal{D}^m$ ，以至少  $1 - \delta$  的概率有

$$\sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| \leq \kappa(\delta, m),$$

则称  $\kappa$  为  $\mathcal{H}$  的泛化界 (generalization bound)。

**注 14.7：** 对泛化界  $\kappa$ ，只要  $m$  足够大，使得  $\kappa(\delta, m) \leq \varepsilon$ ，就有

$$\mathbb{P} \left[ |\mathcal{R}(h_S) - \widehat{\mathcal{R}}_S(h_S)| \leq \varepsilon \right] \geq 1 - \delta.$$

若存在经验风险极小化子  $h_S$  满足  $\widehat{\mathcal{R}}_S(h_S) = 0$ ，则该经验风险极小化子也将以高概率具有较小的风险  $\mathcal{R}(h_S)$ 。经验风险最小化常被称为“PAC”算法，其中 PAC 是很可能 ( $\delta$ ) 近似正确 ( $\varepsilon$ ) (probably approximately correct) 的缩写。◇

定义 14.6 要求经验风险与总体风险之间偏差的上界  $\kappa$  与分布  $\mathcal{D}$  无关. 为什么这可能做到? 毕竟, 底层分布可能并不均匀, 因而某些数据点可能极少出现在样本中. 于是, 对这些点作出正确预测似乎应当非常困难. 乍看之下, 这表明非均匀分布应该比均匀分布困难得多. 但这一直觉并不正确, 下面基于例 14.1 的论证说明了这一点.

**例 14.8** (咖啡品质问题中的泛化): 在例 14.1 中, 底层分布既描述我们选择咖啡的过程, 也描述属性与品质之间的关系. 假设我们不喜欢喝价格低于 1€ 的咖啡. 因此, 数据集中没有任何这种咖啡的样本, 我们也就完全没有机会学习廉价咖啡的品质.

然而, 数据集中没有价格低于 1€ 的咖啡样本, 是因为我们通常会避开这种咖啡. 因而, 把价格低于 1€ 的咖啡品质错误分类的风险很低, 因为将来选择这种咖啡的可能性也很低.  $\diamond$

为了建立泛化界, 我们使用随机工具来保证随着样本量增加, 经验风险收敛到真实风险. 这通常借助集中不等式来实现. 最简单且最著名的集中不等式之一是 Hoeffding 不等式, 见定理 A.24. 现在应用 Hoeffding 不等式得到第一个泛化界. 这个泛化界是众所周知的, 在许多机器学习教材中都可以找到, 例如文献 [202, 285]. 尽管这一结果尚未涵盖神经网络, 但它构成了适用于神经网络的类似结果的基础, 后文将对此加以讨论.

**命题 14.9** (有限假设集): 设  $\mathcal{H} \subseteq \{h: X \mapsto Y\}$  是一个有限假设集. 设  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}$  满足  $\mathcal{L}(Y \times Y) \subseteq [c_1, c_2]$ , 其中  $c_2 - c_1 = C > 0$ .

则对每个  $m \in \mathbb{N}$  以及  $X \times Y$  上的每个分布  $\mathcal{D}$ , 关于样本  $S \sim \mathcal{D}^m$ , 以至少  $1 - \delta$  的概率有

$$\sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| \leq C \sqrt{\frac{\log(|\mathcal{H}|) + \log(2/\delta)}{2m}}.$$

**证明:** 设  $\mathcal{H} = \{h_1, \dots, h_n\}$ . 由并集界, 有

$$\mathbb{P} \left[ \exists h_i \in \mathcal{H} : |\mathcal{R}(h_i) - \widehat{\mathcal{R}}_S(h_i)| > \varepsilon \right] \leq \sum_{i=1}^n \mathbb{P} \left[ |\mathcal{R}(h_i) - \widehat{\mathcal{R}}_S(h_i)| > \varepsilon \right].$$

注意,  $\widehat{\mathcal{R}}_S(h_i)$  是一组独立随机变量的均值, 而这些随机变量几乎必然取值于  $[c_1, c_2]$ . 此外,  $\mathcal{R}(h_i)$  是  $\widehat{\mathcal{R}}_S(h_i)$  的期望. 因此, 应用定理 A.24 即可完成证明. 习题 14.31 将处理这一点.  $\square$

现在考虑一个非有限的神经网络集合  $\mathcal{H}$ , 并假设它可由有限个 (小) 球覆盖. 把命题 14.9 应用于这些球的中心, 便可对  $\mathcal{H}$  推导出与该命题类似的界. 下一节将严格论证这一直观想法.

## 14.4 由覆盖数导出的泛化界

为了导出神经网络类的泛化界, 首先引入覆盖数的概念.

**定义 14.10:** 设  $A$  是度量空间  $(X, d)$  的一个相对紧子集. 对  $\varepsilon > 0$ , 称

$$\mathcal{G}(A, \varepsilon, (X, d)) := \min \left\{ n \in \mathbb{N} \mid \exists (x_i)_{i=1}^n \subseteq X \text{ 使得 } \bigcup_{i=1}^n B_\varepsilon(x_i) \supset A \right\},$$

为  $A$  在  $X$  中的  $\varepsilon$ -覆盖数 ( $\varepsilon$ -covering number), 其中  $B_\varepsilon(x) = \{z \in X \mid d(z, x) \leq \varepsilon\}$ . 当由上下文可以明确  $X$  或  $d$  时, 也分别用  $\mathcal{G}(A, \varepsilon, d)$  或  $\mathcal{G}(A, \varepsilon, X)$  代替  $\mathcal{G}(A, \varepsilon, (X, d))$ .

图 14.2 给出了定义 14.10 的可视化.




图 14.2: 定义 14.10 中覆盖数概念的示意图. 阴影集合  $A \subseteq \mathbb{R}^2$  被 16 个半径为  $\varepsilon$  的 Euclidean 球覆盖. 因此,  $\mathcal{G}(A, \varepsilon, \mathbb{R}^2) \leq 16$ .

正如下文将看到的, 对 Lipschitz 连续激活函数, 当权重限制在一个固定有界集合中时, 可以对作为  $C^0([0, 1]^d)$  子集的神经网络的  $\varepsilon$ -覆盖数给出上界. 精确估计推迟到第 14.5 节. 在此之前, 先说明有限覆盖数如何给出泛化界. 下面的结果仅考虑 Euclidean 特征空间  $X$ ; 不难导出更一般的版本. 在陈述结果时, 回顾: 对  $h: X \rightarrow \mathbb{R}$ ,  $\|h\|_\infty := \sup_{x \in X} |h(x)|$  表示上确界范数.

**定理 14.11:** 设  $C_Y, C_{\mathcal{L}} > 0$  且  $\alpha > 0$ . 设  $Y \subseteq [-C_Y, C_Y]$ , 对某个  $d \in \mathbb{N}$  有  $X \subseteq \mathbb{R}^d$ , 并设  $\mathcal{H} \subseteq \{h: X \rightarrow Y\}$ . 再设  $\mathcal{L}: Y \times Y \rightarrow \mathbb{R}$  关于第一个坐标是  $C_{\mathcal{L}}$ -Lipschitz 的, 即

$$|\mathcal{L}(y, \tilde{y}) - \mathcal{L}(z, \tilde{y})| \leq C_{\mathcal{L}}|y - z| \quad \text{对所有 } \tilde{y}, y, z \in Y.$$

则对  $X \times Y$  上的每个分布  $\mathcal{D}$  和每个  $m \in \mathbb{N}$ , 关于样本  $S \sim \mathcal{D}^m$ , 以至少  $1 - \delta$  的概率, 对所有  $h \in \mathcal{H}$  都有

$$|\mathcal{R}(h) - \hat{\mathcal{R}}_S(h)| \leq 4C_Y C_{\mathcal{L}} \sqrt{\frac{\log(\mathcal{G}(\mathcal{H}, m^{-\alpha}, (X, \|\cdot\|_\infty))) + \log(2/\delta)}{m}} + \frac{2C_{\mathcal{L}}}{m^\alpha}.$$

**证明:** 设

$$M = \mathcal{G}(\mathcal{H}, m^{-\alpha}, (X, \|\cdot\|_\infty)), \quad (14.4.1)$$

并取  $\mathcal{H}_M = (h_i)_{i=1}^M \subseteq \{h: X \rightarrow Y\}$ , 使得对每个  $h \in \mathcal{H}$ , 都存在  $h_i \in \mathcal{H}_M$  满足  $\|h - h_i\|_\infty \leq m^{-\alpha}$ .  $\mathcal{H}_M$  的存在性由定义 14.10 得到.

暂时固定这样的  $h \in \mathcal{H}$  和  $h_i \in \mathcal{H}_M$ . 由反三角不等式和三角不等式, 有

$$|\mathcal{R}(h) - \hat{\mathcal{R}}_S(h)| - |\mathcal{R}(h_i) - \hat{\mathcal{R}}_S(h_i)| \leq |\mathcal{R}(h) - \mathcal{R}(h_i)| + |\hat{\mathcal{R}}_S(h) - \hat{\mathcal{R}}_S(h_i)|.$$

此外，由期望的单调性和  $\mathcal{L}$  的 Lipschitz 性质，得到

$$\begin{aligned} |\mathcal{R}(h) - \mathcal{R}(h_i)| &\leq \mathbb{E}|\mathcal{L}(h(x), y) - \mathcal{L}(h_i(x), y)| \\ &\leq C_{\mathcal{L}} \mathbb{E}|h(x) - h_i(x)| \leq \frac{C_{\mathcal{L}}}{m^{\alpha}}. \end{aligned}$$

类似的估计给出  $|\widehat{\mathcal{R}}_S(h) - \widehat{\mathcal{R}}_S(h_i)| \leq C_{\mathcal{L}}/m^{\alpha}$ .

因此，对每个  $\varepsilon > 0$ ，有

$$\begin{aligned} \mathbb{P}_{S \sim \mathcal{D}^m} \left[ \exists h \in \mathcal{H} : |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| \geq \varepsilon \right] \\ \leq \mathbb{P}_{S \sim \mathcal{D}^m} \left[ \exists h_i \in \mathcal{H}_M : |\mathcal{R}(h_i) - \widehat{\mathcal{R}}_S(h_i)| \geq \varepsilon - \frac{2C_{\mathcal{L}}}{m^{\alpha}} \right]. \end{aligned} \quad (14.4.2)$$

由命题 14.9，对  $\varepsilon > 0$  和  $\delta \in (0, 1)$ ，有

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ \exists h_i \in \mathcal{H}_M : |\mathcal{R}(h_i) - \widehat{\mathcal{R}}_S(h_i)| \geq \varepsilon - \frac{2C_{\mathcal{L}}}{m^{\alpha}} \right] \leq \delta. \quad (14.4.3)$$

只要

$$\varepsilon - \frac{2C_{\mathcal{L}}}{m^{\alpha}} > C \sqrt{\frac{\log(M) + \log(2/\delta)}{2m}}.$$

这里  $C$  满足  $\mathcal{L}(Y \times Y) \subseteq [c_1, c_2]$  且  $c_2 - c_1 \leq C$ . 由  $\mathcal{L}$  的 Lipschitz 性质，可以取  $C = 2\sqrt{2}C_{\mathcal{L}}C_Y$ .

因此，由式 (14.4.1) 中  $M$  的定义以及式 (14.4.2) 和 (14.4.3)，以至少  $1 - \delta$  的概率，对所有  $h \in \mathcal{H}$  都有

$$|\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| \leq 2\sqrt{2}C_{\mathcal{L}}C_Y \sqrt{\frac{\log(\mathcal{G}(\mathcal{H}, m^{-\alpha}, (X, \|\cdot\|_{\infty}))) + \log(2/\delta)}{2m}} + \frac{2C_{\mathcal{L}}}{m^{\alpha}}.$$

这就完成了证明. □

## 14.5 深度神经网络的覆盖数

我们已经在定理 14.11 中看到，估计  $\|\cdot\|_{\infty}$ -覆盖数对于理解泛化误差至关重要. 应当如何确定这些覆盖数？固定架构的神经网络集合可能相当复杂（见第 13 章），因此，如何用球覆盖它，更不用说确定所需球的数目，并非显而易见. 下面的引理给出了一种更简单的方法.

**引理 14.12：** 设  $X_1, X_2$  是两个度量空间，且  $f: X_1 \rightarrow X_2$  是  $C_{\text{Lip}}$ -Lipschitz 连续的. 则对每个相对紧集  $A \subseteq X_1$  和所有  $\varepsilon > 0$ ，都有

$$\mathcal{G}(f(A), C_{\text{Lip}}\varepsilon, X_2) \leq \mathcal{G}(A, \varepsilon, X_1).$$

引理 14.12 的证明留作习题 14.33. 如果能够把神经网络集合表示为一个 Lipschitz 映射作用于另一个具有已知覆盖数的集合所得的像，那么引理 14.12 就给出了界定神经网络类覆盖数的直接方法.



方便的是，我们已经在命题 13.1 中观察到，神经网络集合是定义 12.1 中参数范围  $\mathcal{PN}(\mathcal{A}, B)$  在 Lipschitz 连续实现映射  $R_\sigma$  下的像。因而，只需确定  $\mathcal{PN}(\mathcal{A}, B)$  的  $\varepsilon$ -覆盖数，等价地，确定  $[-B, B]^{n_{\mathcal{A}}}$  的  $\varepsilon$ -覆盖数。随后应用引理 14.12，即可得到  $\mathcal{N}(\sigma; \mathcal{A}, B)$  的覆盖数。图 14.3 展示了这一思路。




图 14.3: 推导神经网络空间覆盖数的主要思路示意图。左图参数空间中的点  $\theta \in \mathbb{R}^2$  对应于右图中的函数  $R_\sigma(\theta)$ （颜色相同者相互对应）。由引理 14.12，左侧参数空间的一个覆盖会转化为右侧函数空间的一个覆盖。

**命题 14.13:** 设  $B, \varepsilon > 0$  且  $s \in \mathbb{N}$ 。则

$$\mathcal{G}([-B, B]^s, \varepsilon, (\mathbb{R}^s, \|\cdot\|_\infty)) \leq \lceil B/\varepsilon \rceil^s.$$

**证明:** 先设  $s = 1$ 。区间  $[-B, B]$  的长度为  $2B$ ，因此可由  $\lceil 2B/(2\varepsilon) \rceil = \lceil B/\varepsilon \rceil$  个长度为  $2\varepsilon$  的闭区间覆盖。所以  $\mathcal{G}([-B, B], \varepsilon, \mathbb{R}) \leq \lceil B/\varepsilon \rceil$ 。

当  $s > 1$  时，这些区间的 Cartesian 积覆盖  $[-B, B]^s$ 。这样的 Cartesian 积恰有  $\lceil B/\varepsilon \rceil^s$  个，而每一个都对应于范数  $\|\cdot\|_\infty$  下半径为  $\varepsilon$  的球，故  $\mathcal{G}([-B, B]^s, \varepsilon, \|\cdot\|_\infty) \leq \lceil B/\varepsilon \rceil^s$ 。□

已经确定  $[-B, B]^s$  的覆盖数之后，现在可以结合引理 14.12 与命题 13.1、14.13 来估计深度神经网络的覆盖数。首先形式化具有  $s$  个可训练参数的网络集合（另见定义 12.1 中的  $\mathcal{N}(\sigma; \mathcal{A}, B)$ ）。因此，下面的  $s$  表示这些网络的大小。

**定义 14.14:** 设  $B \geq 0$ ,  $L, s, d_0, d_{L+1} \in \mathbb{N}$ ，并且对  $\ell = 1, \dots, L$ ，令

$$\mathcal{A}_\ell := (d_0, \underbrace{s, \dots, s}_{\ell \text{ 次}}, d_{L+1}) \in \mathbb{N}^{\ell+2},$$

$$n_{\mathcal{A}_\ell} := (d_0 + 1)s + (\ell - 1)s(s + 1) + (s + 1)d_{L+1} \in \mathbb{N}.$$

则

$$\mathcal{N}^{\text{sp}}(\sigma; L, B, s) := \left\{ \Phi(\cdot, \mathbf{w} \odot \mathbf{s}) \mid \Phi \in \mathcal{N}(\sigma; \mathcal{A}_\ell, B), \text{ 其中 } 1 \leq \ell \leq L, \right.$$

$$\left. \mathbf{w} \in [-B, B]^{n_{\mathcal{A}_\ell}}, \mathbf{s} \in \{0, 1\}^{n_{\mathcal{A}_\ell}}, \sum_{j=1}^{n_{\mathcal{A}_\ell}} s_j = s \right\}$$

为深度至多为  $L$  的稀疏连接网络 (sparsely connected networks) 集合。

换言之,  $\mathcal{N}^{\text{sp}}(\sigma; L, B, s)$  表示如下前馈神经网络的集合: 激活函数为  $\sigma$ , 至少有一个隐藏层且至多有  $L$  个隐藏层, 至多有  $N$  个非零权重, 并且所有权重的绝对值均不超过  $B$ . 数  $n_{\mathcal{A}_\ell}$  是定义中架构  $\mathcal{A}_\ell$  可能具有的最大权重数.

**定理 14.15:** 设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是  $C_\sigma$ -Lipschitz 连续的, 其中  $C_\sigma \geq 1$ , 并且  $|\sigma(x)| \leq C_\sigma(1 + |x|)$ . 此外, 设  $\mathcal{N}^{\text{sp}}(\sigma; L, B, s)$  如定义 14.14 所述, 并假设  $N \geq \max\{d_0, d_{L+1}\}$ .

则对所有  $\varepsilon > 0$ , 有

$$\mathcal{G}(\mathcal{N}^{\text{sp}}(\sigma; L, B, s), \varepsilon, C^0([0, 1]^{d_0})) \leq (s+1)^{7sL} [3C_\sigma B]^{2sL} [1/\varepsilon]^s.$$

**证明:** 沿用定义 14.14 中的记号, 并令  $S_\ell := \{\mathbf{s} \in \{0, 1\}^{n_{\mathcal{A}_\ell}} \mid |\mathbf{s}| = s\}$ . 对  $\mathbf{s} \in S_\ell$ , 以  $\mathcal{N}^{\text{sp}}(\sigma; \mathcal{A}_\ell, B, \mathbf{s})$  表示  $\mathcal{N}^{\text{sp}}(\sigma; L, B, s)$  中架构为  $\mathcal{A}_\ell$ 、且仅在  $s_j = 1$  的位置具有非零权重的神经网络. 则

$$\mathcal{N}^{\text{sp}}(\sigma; L, B, s) = \bigcup_{\ell=1}^L \bigcup_{\mathbf{s} \in S_\ell} \mathcal{N}^{\text{sp}}(\sigma; \mathcal{A}_\ell, B, \mathbf{s}).$$

因此, 对  $\varepsilon > 0$ ,  $\mathcal{N}^{\text{sp}}(\sigma; L, B, s)$  的覆盖数由下式界定:

$$\sum_{\ell=1}^L \sum_{\mathbf{s} \in S_\ell} \mathcal{G}(\mathcal{N}(\sigma; \mathcal{A}_\ell, B, \mathbf{s}), \varepsilon, C^0([0, 1]^{d_0})). \quad (14.5.1)$$

固定  $1 \leq \ell \leq L$ . 集合  $\mathcal{N}(\sigma; \mathcal{A}_\ell, B, \mathbf{s})$  是  $[-B, B]^s$  在实现映射  $R_\sigma$  下的像. 由命题 13.1,  $R_\sigma$  是  $C_{\text{Lip}, \ell}$ -Lipschitz 连续的, 其中

$$C_{\text{Lip}, \ell} := (3C_\sigma B d_{\max})^\ell s \leq (3C_\sigma B s)^\ell s.$$

在这个不等式中, 使用了  $d_0, d_{L+1} \leq s$ , 因而  $d_{\max} \leq s$ . 利用命题 14.13 和引理 14.12, 得到

$$\begin{aligned} \mathcal{G}(\mathcal{N}(\sigma; \mathcal{A}_\ell, B, \mathbf{s}), \varepsilon, C^0([0, 1]^{d_0})) &\leq \left\lceil \frac{BC_{\text{Lip}, \ell}}{\varepsilon} \right\rceil^s \\ &\leq \left\lceil \frac{(3C_\sigma B s)^{L+1} s}{\varepsilon} \right\rceil^s. \end{aligned}$$

其次,  $S_\ell$  的基数等于

$$\binom{n_{\mathcal{A}_\ell}}{s} \leq n_{\mathcal{A}_\ell}^s \leq ((\ell+1)s(s+1))^s \leq (L+1)^s (s+1)^{2s}.$$

因此, 式 (14.5.1) 由下式界定:

$$\begin{aligned} (L+1)^{s+1} (s+1)^{2s} \left\lceil \frac{(3C_\sigma B s)^{L+1} s}{\varepsilon} \right\rceil^s \\ \leq (L+1)^{s+1} (s+1)^{2s+s(L+2)} \left\lceil \frac{(3C_\sigma B)^{L+1}}{\varepsilon} \right\rceil^s. \end{aligned}$$

由于  $s, L \geq 1$ , 有  $L+1 \leq (s+1)^L$ , 从而

$$\begin{aligned} (L+1)^{s+1} (s+1)^{2s+s(L+2)} &\leq (s+1)^{L(s+1)+2s+s(L+2)} \\ &\leq (s+1)^{7Ls}. \end{aligned}$$

这就完成了证明. □



定理 14.15 中的界相当粗糙，但足以用于下文。

最后，把上一定理应用于定理 14.11 在  $\alpha = 1/2$  时的泛化界。为简化分析，把讨论限制在值域为  $[-1, 1]$  的神经网络上。为此，记

$$\mathcal{N}^{\text{sp},*}(\sigma; L, B, s) := \{\Phi \in \mathcal{N}(\sigma; L, B, s) \mid \Phi(\mathbf{x}) \in [-1, 1] \text{ 对所有 } \mathbf{x} \in [0, 1]^{d_0}\}. \quad (14.5.2)$$

由于  $\mathcal{N}^{\text{sp},*}(\sigma; L, B, s) \subseteq \mathcal{N}^{\text{sp}}(\sigma; L, B, s)$ ，前者的覆盖数由后者的覆盖数界定。这就得到下面的结果。

**定理 14.16:** 设  $C_{\mathcal{L}} > 0$ ，并设  $\mathcal{L}: [-1, 1] \times [-1, 1] \rightarrow \mathbb{R}$  是  $C_{\mathcal{L}}$ -Lipschitz 连续的。设  $L, d_0, d_{L+1} \in \mathbb{N}$ ， $B \geq 1$ ，设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是  $C_{\sigma}$ -Lipschitz 连续的，其中  $C_{\sigma} \geq 1$ ，并且对所有  $x \in \mathbb{R}$  都有  $|\sigma(x)| \leq C_{\sigma}(1 + |x|)$ 。

则对每个  $m \in \mathbb{N}$ 、 $[0, 1]^{d_0} \times [-1, 1]$  上的每个分布  $\mathcal{D}$  以及每个  $s \geq \max\{d_0, d_{L+1}\}$ ，关于  $S \sim \mathcal{D}^m$ ，以至少  $1 - \delta$  的概率，对所有  $\Phi \in \mathcal{N}^{\text{sp},*}(\sigma; L, B, s)$  都有

$$|\mathcal{R}(\Phi) - \widehat{\mathcal{R}}_S(\Phi)| \lesssim C_{\mathcal{L}} \sqrt{\frac{sL \log(C_{\sigma}Bs) + s \log(m^{1/2}) + \log(2/\delta)}{m}} + \frac{2C_{\mathcal{L}}}{\sqrt{m}},$$

其中隐含常数是与所有其他量无关的绝对常数。

## 14.6 逼近-复杂度权衡

回顾式 (14.2.2) 中的误差分解

$$\mathcal{R}(h_S) - R^* \leq 2\varepsilon_{\text{gen}} + \varepsilon_{\text{approx}},$$

其中  $R^*$  是式 (14.1.1) 定义的 Bayes 风险。在基于神经网络的学习背景下，对于逼近误差  $\varepsilon_{\text{approx}}$  和泛化误差  $\varepsilon_{\text{gen}}$ ，有以下观察：

- 泛化误差的标度：对假设类  $\mathcal{H} = \mathcal{N}^{\text{sp},*}(\sigma; L, B, s)$  和大小为  $m \in \mathbb{N}$  的样本，由定理 14.16 可知，泛化误差  $\varepsilon_{\text{gen}}$  关于网络大小  $s$ 、网络深度  $L$  和权重上界  $B$  的标度基本为

$$\varepsilon_{\text{gen}} \lesssim \sqrt{\frac{sL \log(mBs)}{m}} + \sqrt{\frac{\log(2/\delta)}{m}}.$$

对每个  $m$ ，该界以至少  $1 - \delta$  的概率成立。

- 逼近误差的标度：假设存在  $h^*$  使得  $\mathcal{R}(h^*) = R^*$ ，并设损失函数  $\mathcal{L}$  关于第一个坐标是  $C_{\mathcal{L}}$ -Lipschitz 连续的。则

$$\begin{aligned} \varepsilon_{\text{approx}} &= \inf_{h \in \mathcal{H}} \mathcal{R}(h) - \mathcal{R}(h^*) = \inf_{h \in \mathcal{H}} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{L}(h(x), y) - \mathcal{L}(h^*(x), y)] \\ &\leq C_{\mathcal{L}} \inf_{h \in \mathcal{H}} \|h - h^*\|_{\infty}. \end{aligned}$$

我们已经在第 5 章和第 7 章看到若干结果：对于大小为  $s$  的网络，逼近误差为  $s^{-\alpha}$ ，其中代数收敛率  $\alpha$  取决于函数的光滑性和底空间的维数；更准确地说，这里假设深度  $L$  和上界  $B$  随  $s$  适当增长。

在这一情形下，对  $\mathcal{N}^{\text{sp},*}(\sigma; L, B, s)$  中的经验风险极小化子  $\Phi_S$ ，以至少  $1 - \delta$  的概率有

$$\mathcal{R}(\Phi_S) - R^* \lesssim \underbrace{\sqrt{\frac{sL \log(mBs)}{m}}}_{\text{泛化误差}} + \underbrace{\sqrt{\frac{\log(2/\delta)}{m}}}_{\text{逼近误差}} + \underbrace{s^{-\alpha}}_{\text{逼近误差}}. \quad (14.6.1)$$

增大网络大小  $s$ 、深度  $L$  和权重界  $B$ ，会对这两项产生相反的影响：逼近误差减小，而与泛化有关的项增大。这种权衡称为逼近-复杂度权衡（approximation-complexity trade-off）。图 14.4 展示了这一情形。该图和式 (14.6.1) 表明，理想模型在逼近误差与泛化误差之间实现最优权衡。利用这一概念，可以把所有模型分为三类：

- 欠拟合：模型对于数据的表达能力不足。由于逼近误差  $\varepsilon_{\text{approx}}$  支配泛化误差  $\varepsilon_{\text{gen}}$ ，总误差很高。增大模型复杂度会减小总误差。
- 最优：模型复杂度在逼近误差与泛化误差之间达到平衡，两项误差之和  $\varepsilon_{\text{approx}} + \varepsilon_{\text{gen}}$  取得最小值。增大或减小模型复杂度都会增大总误差。
- 过拟合：模型对于数据的表达能力过强。由于泛化误差  $\varepsilon_{\text{gen}}$  支配逼近误差  $\varepsilon_{\text{approx}}$ ，总误差很高。虽然模型可能完美拟合数据，但它也会拟合噪声，或引入无法泛化到真实分布的不必要特征。降低模型复杂度会减小误差。




图 14.4: 式 (14.6.1) 中逼近-复杂度权衡的示意图。这里取  $r = 1$ 、 $m = 10,000$ ，并假设所有隐含常数均等于 1。

在第 15 章将看到，深度学习常常在可训练参数数目  $s$  超过最优权衡点的机制下运行。对实践中使用的某些架构，参数数目可能大到使逼近-复杂度权衡理论表明学习应当不可能。但需要强调的是，目前的分析只给出上界；它并未证明在过参数化机制下学习是不可能的，甚至没有证明学习是不切实际的。此外，我们已经在第 11 章第 11.6.4 节看到一些迹象，说明过参数化机制下的学习未必会导致很大的泛化误差。

## 14.7 最优权衡下的风险界

现在确定当神经网络集合依照上一节的最优权衡选取时的泛化界。首先对底层函数类由神经网络逼近的能力作一个抽象假设。

具体而言，假设与网络参数总数相比，深度至多以对数速度增长，而误差以代数速度衰减。此外，也允许网络权重以代数速度增长。这是前面各章的逼近结果中遇到的典型情形。

**假设 14.17:** 设  $d \in \mathbb{N}$ ,  $c, \alpha, \beta > 0$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 设  $\mathcal{C} \subset \{h: [0, 1]^d \rightarrow \mathbb{R}\}$ , 使得对所有  $N \in \mathbb{N}$ , 都存在  $L_N, B_N > 0$  和  $s_N \in \mathbb{N}$  满足:

1.  $s_N \leq cN \log(N)$ ,  $L_N \leq c \log(N+1)$ , 且  $B_N \leq cN^\beta$ ;
2. 对所有  $h \in \mathcal{C}$ , 都存在  $\Phi_{h,N} \in \mathcal{N}^{\text{sp},*}(\sigma; L_N, B_N, s_N)$ , 使得

$$\|h - \Phi_{h,N}\|_{L^\infty([0,1]^d)} \leq cN^{-\alpha}.$$

下文以  $D_{\mathcal{C}}$  表示如下分布的集合：对这些分布，至少存在一个  $h \in \mathcal{C}$  使 Bayes 风险得以达到。

由式 (14.6.1)，在假设 14.17 下，对  $\mathcal{D} \in D_{\mathcal{C}}$ ，关于样本  $S \sim \mathcal{D}^m$ ，以至少  $1 - \delta$  的概率， $\mathcal{N}^*(\sigma; \mathcal{A}_N, B_N)$  中的经验风险极小化子  $\Phi_S$  满足

$$\mathcal{R}(\Phi_S) - R^* \lesssim \sqrt{\frac{N \log(N)^3 \log(m)}{m}} + \frac{1}{N^\alpha} + \sqrt{\frac{\log(2/\delta)}{m}}, \quad (14.7.1)$$

其中使用了对  $N, m \gg 1$  成立的  $\log(Nm) \lesssim \log(N) \log(m)$ ，而隐含常数依赖于  $\beta$ 。对固定的样本大小  $m$ ，希望最优地选取  $N$ ，使右端最小。最后一项不受  $N$  影响。对前两项，试探式  $N = m^\gamma$  给出

$$\sqrt{\frac{N \log^3(N) \log(m)}{m}} = m^{(\gamma-1)/2} \log^2(m) \quad \text{且} \quad \frac{1}{N^\alpha} = m^{-\alpha\gamma}, \quad (14.7.2)$$

这分别对应两个依赖于  $N$  的项。第二项的渐近速率随  $\gamma$  增大，而第一项的渐近速率随  $\gamma$  减小，因此必须使二者平衡。

当  $\gamma = 1/(2\alpha + 1)$  且  $N = N^* := m^{1/(2\alpha+1)}$  时，对某个常数  $c' > 0$ ，式 (14.7.2) 中两项均由  $c'm^{-\alpha/(2\alpha+1)} \log^2(m)$  界定。显然，当  $N > N^*(c' \log^2(m))$  时，式 (14.7.2) 中第一项超过  $cm^{-\alpha/(2\alpha+1)} \log^2(m)$ 。类似地，当  $N < N^*/(c' \log^2(m))^{1/\alpha}$  时，第二项超过  $cm^{-\alpha/(2\alpha+1)} \log^2(m)$ 。因而可以断定，至多相差一个关于  $m$  的对数因子时， $N^*$  给出式 (14.7.1) 中的最佳上界。下面的定理概括了这些观察。

**定理 14.18:** 考虑定理 14.16 的设定, 并设假设 14.17 成立. 则对每个  $m \in \mathbb{N}$ 、每个分布  $\mathcal{D} \in \mathcal{D}_{\mathcal{C}}$  和每个  $\delta \in (0, 1)$ , 关于  $S \sim \mathcal{D}^m$ , 以至少  $1 - \delta$  的概率, 经验风险极小化子<sup>8</sup>  $\Phi_S \in \mathcal{N}^{\text{sp},*}(\sigma; L_{N^*}, B_{N^*}, s_{N^*})$ , 其中  $N^* = m^{1/(2\alpha+1)}$ , 满足

$$\mathcal{R}(\Phi_S) - R^* \lesssim m^{-\frac{\alpha}{1+2\alpha}} \log^2(m) + \sqrt{\frac{\log(2/\delta)}{m}}.$$

**注 14.19:** 现在讨论本书中可以应用定理 14.18 的两个结果.

- $C^{k,s}$  函数 (定理 7.11): 设  $\mathcal{C}$  是  $C^{k,s}([0, 1]^d)$  中的单位球. 由定理 7.11, 对  $\alpha = (k+s)/d$  的 ReLU 神经网络, 假设 14.17 的条件 1 成立; 定理 7.11 中没有显式导出权重上界, 但仔细检查证明可以看出, 可选取这些上界, 使假设 14.17 对某个  $\beta$  成立. 因此, 以至少  $1 - \delta$  的概率有

$$\mathcal{R}(\Phi_S) \lesssim m^{-\frac{k+s}{2k+2s+d}} \log^2(m) + \sqrt{\frac{\log(2/\delta)}{m}}.$$

- Barron 函数 (定理 8.12): 该定理只给出  $L^2$  中的逼近率, 这不足以满足假设 14.17. 然而, 逼近结果可以推广到  $L^\infty$ , 见文献 [16]; 由此假设 14.17 对  $\alpha = 1/2$  (以及某个  $\beta > 0$ ) 成立. 这蕴含风险界

$$\mathcal{R}(\Phi) \lesssim m^{-1/4} \log^2(m) + \sqrt{\frac{\log(2/\delta)}{m}},$$

该界以概率  $1 - \delta$  成立.

◇

**注 14.20:** 所得速率只使用了损失函数的 Lipschitz 性质, 对特定损失而言未必最优. 例如, 对平方损失, 速率通常可以加倍: 文献 [274] 对  $C^{k,s}$  正则函数建立了量级为  $m^{-2/((k+s)/d+2)} = m^{-(2k+2s)/(d+2k+2s)}$  的风险上界, 而文献 [18] 证明, 对 Barron 正则函数和适当选取的神经网络空间, 风险按  $m^{-1/2}$  衰减.

◇

## 14.8 由 VC 维得到 PAC 学习

除覆盖数外, 还有其他若干工具可以分析假设集的泛化能力. 在分类问题的背景下, 其中最重要的工具之一是所谓的 Vapnik–Chervonenkis (VC) 维.

### 14.8.1 定义与例子

设  $\mathcal{H}$  是从  $\mathbb{R}^d$  映到  $\{0, 1\}$  的函数构成的假设集. 如果对每个  $(y_1, \dots, y_n) \in \{0, 1\}^n$ , 都存在  $h \in \mathcal{H}$ , 使得对所有  $j = 1, \dots, n$  均有  $h(\mathbf{x}_j) = y_j$ , 则称集合  $S = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subseteq \mathbb{R}^d$  被  $\mathcal{H}$  打散 (shattered).

VC 维通过可被打散的点数来量化函数类的复杂度.

<sup>8</sup>这里隐含假设该经验风险极小化子作为样本  $S$  的函数是可测的. 在某些假设下, 可以严格表述这类陈述 (例如参见文献 [218, 命题 5]、[248]), 但这里不再深入讨论.




图 14.5: 对两个点或三个点进行分类的不同方式. 彩色色块对应于能够对这些点产生不同分类的区间.

**定义 14.21:**  $\mathcal{H}$  的 VC 维 (VC dimension) 是被  $\mathcal{H}$  打散的最大集合  $S \subseteq \mathbb{R}^d$  的基数. 以  $\text{VCdim}(\mathcal{H})$  表示 VC 维.

**例 14.22 (区间):** 设  $\mathcal{H} = \{\mathbb{1}_{[a,b]} \mid a, b \in \mathbb{R}\}$ . 显然  $\text{VCdim}(\mathcal{H}) \geq 2$ , 因为当  $x_1 < x_2$  时, 函数

$$\mathbb{1}_{[x_1-2, x_1-1]}, \quad \mathbb{1}_{[x_1-1, x_1]}, \quad \mathbb{1}_{[x_1, x_2]}, \quad \mathbb{1}_{[x_2, x_2+1]}$$

限制在  $S = \{x_1, x_2\}$  上时彼此不同.

另一方面, 若  $x_1 < x_2 < x_3$ , 则由于对所有  $h \in \mathcal{H}$ ,  $h^{-1}(\{1\})$  都是区间,  $h(x_1) = 1 = h(x_3)$  蕴含  $h(x_2) = 1$ . 因此, 不存在可被打散的三元素集合, 从而  $\text{VCdim}(\mathcal{H}) = 2$ . 图 14.5 展示了这一情形.  $\diamond$

**例 14.23 (半空间):** 设  $\mathcal{H}_2 = \{\mathbb{1}_{[0,\infty)}(\langle \mathbf{w}, \cdot \rangle + b) \mid \mathbf{w} \in \mathbb{R}^2, b \in \mathbb{R}\}$  是由经过旋转和平移的二维半空间构成的假设集. 从图 14.6 可见,  $\mathcal{H}_2$  可以打散一个三点集合. 更一般地, 对  $d \geq 2$ , 令

$$\mathcal{H}_d := \{\mathbf{x} \mapsto \mathbb{1}_{[0,\infty)}(\mathbf{w}^\top \mathbf{x} + b) \mid \mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}\},$$

则  $\mathcal{H}_d$  的 VC 维等于  $d + 1$ .  $\diamond$




图 14.6: 用半空间对三个点进行分类的不同方式, 见文献 [278, 图 1.4].

在上例中, VC 维与参数数目相同. 然而, 一般情形并非如此, 下面的例子说明了这一点.

**例 14.24** (无穷 VC 维): 对  $x \in \mathbb{R}$ , 令

$$\mathcal{H} := \{x \mapsto \mathbb{1}_{[0, \infty)}(\sin(wx)) \mid w \in \mathbb{R}\}.$$

则  $\mathcal{H}$  的 VC 维为无穷 (习题 14.34) . ◇

### 14.8.2 基于 VC 维的泛化

下文考虑一个分类问题. 以  $\mathcal{D}$  表示  $\mathbb{R}^d \times \{0, 1\}$  上生成数据的分布, 并设  $\mathcal{H}$  是从  $\mathbb{R}^d$  映到  $\{0, 1\}$  的函数集合.

在二元分类设定中, 损失函数的自然选择是 0-1 损失  $\mathcal{L}_{0-1}(y, y') = \mathbb{1}_{y \neq y'}$ . 因而, 给定样本  $S$ , 函数  $h \in \mathcal{H}$  的经验风险为

$$\widehat{\mathcal{R}}_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{h(x_i) \neq y_i}.$$

此外, 风险可写成

$$\mathcal{R}(h) = \mathbb{P}_{(\mathbf{x}, y) \sim \mathcal{D}}[h(\mathbf{x}) \neq y],$$

即在  $(\mathbf{x}, y) \sim \mathcal{D}$  下,  $h$  错误分类  $\mathbf{x}$  的标签  $y$  的概率.

现在可以用  $\mathcal{H}$  的 VC 维给出泛化界, 例如见文献 [202, 推论 3.19].

**定理 14.25:** 设  $d, k \in \mathbb{N}$ , 且  $\mathcal{H} \subseteq \{h: \mathbb{R}^d \rightarrow \{0, 1\}\}$  的 VC 维为  $k$ . 设  $\mathcal{D}$  是  $\mathbb{R}^d \times \{0, 1\}$  上的一个分布. 则对每个  $\delta \in (0, 1)$  和满足  $m \geq k$  的  $m \in \mathbb{N}$ , 关于样本  $S \sim \mathcal{D}^m$ , 以至少  $1 - \delta$  的概率, 对每个  $h \in \mathcal{H}$  都有

$$|\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| \leq \sqrt{\frac{2k \log(em/k)}{m}} + \sqrt{\frac{\log(1/\delta)}{2m}}, \quad (14.8.1)$$

其中  $e$  是自然对数的底.

换言之, 定理 14.25 表明, 如果一个假设类具有有限 VC 维, 那么当样本数很大时, 经验风险较小的假设也将具有较小风险. 这说明经验风险最小化在这一情形下是一种可行的策略. 如果 VC 维无界, 这种方法还有效吗? 答案是否定的; 事实上, 此时不存在能够可靠地产生风险接近最佳可能值之假设的学习算法. 下面定理来自文献 [202, 定理 3.23], 这里略去其技术性证明.

**定理 14.26:** 设  $k \in \mathbb{N}$ , 并设假设集  $\mathcal{H} \subseteq \{h: X \rightarrow \{0, 1\}\}$  的 VC 维为  $k$ . 则对每个  $m \in \mathbb{N}$  和每个学习算法<sup>9</sup>  $A: (X \times \{0, 1\})^m \rightarrow \mathcal{H}$ , 都存在  $X \times \{0, 1\}$  上的一个分布  $\mathcal{D}$ , 使得

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ \mathcal{R}(A(S)) - \inf_{h \in \mathcal{H}} \mathcal{R}(h) > \sqrt{\frac{k}{320m}} \right] \geq \frac{1}{64}.$$

定理 14.26 立即蕴含下面关于泛化界的陈述.

<sup>9</sup> 这里的学习算法是指任意映射  $A: (X \times \{0, 1\})^m \rightarrow \mathcal{H}$ , 且  $\mathcal{R} \circ A$  可测.



**推论 14.27:** 设  $k \in \mathbb{N}$ , 并设假设集  $\mathcal{H} \subseteq \{h: X \rightarrow \{0,1\}\}$  的 VC 维为  $k$ . 则对每个  $m \in \mathbb{N}$ , 都存在  $X \times \{0,1\}$  上的一个分布  $\mathcal{D}$ , 使得

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[ \sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| > \sqrt{\frac{k}{1280m}} \right] \geq \frac{1}{64}.$$

**证明:** 对样本  $S$ , 设  $h_S \in \mathcal{H}$  是一个经验风险极小化子, 即  $\widehat{\mathcal{R}}_S(h_S) = \min_{h \in \mathcal{H}} \widehat{\mathcal{R}}_S(h)$ . 设  $\mathcal{D}$  为定理 14.26 中的分布. 此外, 对  $\delta > 0$ , 取  $h_\delta \in \mathcal{H}$  使得

$$\mathcal{R}(h_\delta) - \inf_{h \in \mathcal{H}} \mathcal{R}(h) < \delta.$$

于是

$$\begin{aligned} 2 \sup_{h \in \mathcal{H}} |\mathcal{R}(h) - \widehat{\mathcal{R}}_S(h)| &\geq |\mathcal{R}(h_S) - \widehat{\mathcal{R}}_S(h_S)| + |\mathcal{R}(h_\delta) - \widehat{\mathcal{R}}_S(h_\delta)| \\ &\geq \mathcal{R}(h_S) - \widehat{\mathcal{R}}_S(h_S) + \widehat{\mathcal{R}}_S(h_\delta) - \mathcal{R}(h_\delta) \\ &\geq \mathcal{R}(h_S) - \mathcal{R}(h_\delta) \\ &> \mathcal{R}(h_S) - \inf_{h \in \mathcal{H}} \mathcal{R}(h) - \delta, \end{aligned}$$

其中第三个不等式使用了  $\widehat{\mathcal{R}}_S(h_\delta) \geq \widehat{\mathcal{R}}_S(h_S)$ . 在定理 14.26 中取  $A(S) = h_S$ , 再利用  $\delta > 0$  的任意性, 即完成证明.  $\square$

现在已经看到, 当且仅当假设类的 VC 维有限时, 随着  $m \rightarrow \infty$ , 存在按  $O(1/\sqrt{m})$  标度的泛化界. 更定量地说, 需要神经网络的 VC 维小于  $m$ .

这对神经网络函数意味着什么? 对 ReLU 神经网络, 有下面的结果, 见文献 [8, 定理 8.8].

**定理 14.28:** 设  $\mathcal{A} \in \mathbb{N}^{L+2}$ ,  $L \in \mathbb{N}$ , 并令

$$\mathcal{H} := \{\mathbf{1}_{[0,\infty)} \circ \Phi \mid \Phi \in \mathcal{N}(\sigma_{\text{ReLU}}; \mathcal{A}, \infty)\}.$$

则存在与  $L$  和  $\mathcal{A}$  无关的常数  $C > 0$ , 使得

$$\text{VCdim}(\mathcal{H}) \leq C(n_{\mathcal{A}}L \log(n_{\mathcal{A}}) + n_{\mathcal{A}}L^2).$$

当样本大小  $m$  显著大于 VC 维  $k$  时, 式 (14.8.1) 中的界才有意义. 对定理 14.28 中的 ReLU 神经网络, 这意味着  $m \gg n_{\mathcal{A}}L \log(n_{\mathcal{A}}) + n_{\mathcal{A}}L^2$ . 固定  $L = 1$ , 对具有  $n_{\mathcal{A}}$  个参数的浅层神经网络, 这归结为  $m \gg n_{\mathcal{A}} \log(n_{\mathcal{A}})$ . 这与第 11 章的假设形成对比; 在那里,  $n_{\mathcal{A}}$  足够大至关重要. 如果神经网络集合的 VC 维按  $O(n_{\mathcal{A}} \log(n_{\mathcal{A}}))$  标度, 那么定理 14.26 和推论 14.27 表明, 至少对某些分布, 在过参数化机制  $n_{\mathcal{A}} \gg m$  下应当无法泛化. 将在第 15 章讨论这一潜在悖论的解决方式.

## 14.9 可达到逼近率的下界

本章最后利用定理 14.28 已建立的 VC 维界, 推导 ReLU 神经网络逼近能力的限制, 从而结束对神经网络复杂度与泛化界的讨论. 下面的结果最早由文献 [332] 给出. 其证明在概念上类似于第 8.1 节的分析; 区别在于这里不假设权重赋值连续, 并且把论证具体化到 ReLU 神经网络.



**定理 14.29:** 设  $k, d \in \mathbb{N}$ . 假设对每个  $\varepsilon > 0$ , 都存在  $L_\varepsilon \in \mathbb{N}$  和具有  $L_\varepsilon$  层、输入维数为  $d$  的  $\mathcal{A}_\varepsilon$ , 使得

$$\sup_{\|f\|_{C^k([0,1]^d)} \leq 1} \inf_{\Phi \in \mathcal{N}(\sigma_{\text{ReLU}}; \mathcal{A}_\varepsilon, \infty)} \|f - \Phi\|_{C^0([0,1]^d)} < \frac{\varepsilon}{2}.$$

则存在仅依赖于  $k$  和  $d$  的常数  $C > 0$ , 使得对所有  $\varepsilon \in (0, 1)$ , 都有

$$n_{\mathcal{A}_\varepsilon} L_\varepsilon \log(n_{\mathcal{A}_\varepsilon}) + n_{\mathcal{A}_\varepsilon} L_\varepsilon^2 \geq C \varepsilon^{-d/k}.$$

**证明:** 对  $\mathbf{x} \in \mathbb{R}^d$ , 回顾式 (8.1.3) 中引入的鼓包函数

$$\psi(\mathbf{x}) := \begin{cases} \exp\left(1 - \frac{1}{1 - \|\mathbf{x}\|_2^2}\right), & \text{若 } \|\mathbf{x}\|_2 < 1, \\ 0, & \text{其他情形.} \end{cases}$$

对  $\varepsilon \in (0, 1)$ , 考虑其缩放版本

$$\tilde{\psi}_\varepsilon(\mathbf{x}) := \varepsilon \tilde{\psi}(2\varepsilon^{-1/k} \mathbf{x}).$$

与引理 8.2 一样, 对某个常数  $\tau_k$  和所有  $\varepsilon \in (0, 1)$ , 有

$$\text{supp}(\tilde{\psi}_\varepsilon) \subseteq \left[-\frac{\varepsilon^{-1/k}}{2}, \frac{\varepsilon^{-1/k}}{2}\right]^d \quad \text{且} \quad \|\tilde{\psi}_\varepsilon\|_{C^k} \leq \tau_k.$$

考虑等距点集  $\{\mathbf{x}_1, \dots, \mathbf{x}_{N(\varepsilon)}\} = \varepsilon^{1/k} \mathbb{Z}^d \cap [0, 1]^d$ , 其基数为  $N(\varepsilon) \simeq \varepsilon^{-d/k}$ . 给定  $\mathbf{y} \in \{0, 1\}^{N(\varepsilon)}$ , 对  $\mathbf{x} \in \mathbb{R}^d$ , 令

$$f_{\mathbf{y}}(\mathbf{x}) := \tau_k^{-1} \sum_{j=1}^{N(\varepsilon)} y_j \tilde{\psi}_\varepsilon(\mathbf{x} - \mathbf{x}_j). \quad (14.9.1)$$

则对所有  $j = 1, \dots, N(\varepsilon)$ , 都有  $f_{\mathbf{y}}(\mathbf{x}_j) = \tau_k^{-1} \varepsilon y_j$ , 并且  $\|f_{\mathbf{y}}\|_{C^k} \leq 1$ .

对每个  $\mathbf{y} \in \{0, 1\}^{N(\varepsilon)}$ , 取  $\Phi_{\mathbf{y}} \in \mathcal{N}(\sigma_{\text{ReLU}}; \mathcal{A}_{\tau_k^{-1}\varepsilon}, \infty)$ , 使得

$$\sup_{\mathbf{x} \in [0, 1]^d} |f_{\mathbf{y}}(\mathbf{x}) - \Phi_{\mathbf{y}}(\mathbf{x})| < \frac{\varepsilon}{2\tau_k}.$$

于是

$$\mathbf{1}_{[0, \infty)} \left( \Phi_{\mathbf{y}}(\mathbf{x}_j) - \frac{\varepsilon}{2\tau_k} \right) = y_j \quad \text{对所有 } j = 1, \dots, N(\varepsilon).$$

因此,  $\mathcal{N}(\sigma_{\text{ReLU}}; \mathcal{A}_{\tau_k^{-1}\varepsilon}, \infty)$  的 VC 维不小于  $N(\varepsilon)$ . 由定理 14.28, 得到

$$\begin{aligned} N(\varepsilon) \simeq \varepsilon^{-d/k} &\leq C \left( n_{\mathcal{A}_{\tau_k^{-1}\varepsilon}} L_{\tau_k^{-1}\varepsilon} \log(n_{\mathcal{A}_{\tau_k^{-1}\varepsilon}}) \right. \\ &\quad \left. + n_{\mathcal{A}_{\tau_k^{-1}\varepsilon}} L_{\tau_k^{-1}\varepsilon}^2 \right), \end{aligned}$$

或者等价地,

$$\tau_k^{-d/k} \varepsilon^{-d/k} \leq C \left( n_{\mathcal{A}_\varepsilon} L_\varepsilon \log(n_{\mathcal{A}_\varepsilon}) + n_{\mathcal{A}_\varepsilon} L_\varepsilon^2 \right).$$

这就完成了证明. □




图 14.7: 式 (14.9.1) 中  $f_y$  在  $[0, 1]^2$  上的示意图.

为解释定理 14.29, 考虑两种情形:

1. 深度至多关于  $\varepsilon$  对数增长: 在这种情形下, 要对所有满足  $\|f\|_{C^k([0,1]^d)} \leq 1$  的  $f \in C^k([0,1]^d)$  达到一致误差  $\varepsilon$ , 需要

$$n_{\mathcal{A}_\varepsilon} \log(n_{\mathcal{A}_\varepsilon}) \log(\varepsilon) + n_{\mathcal{A}_\varepsilon} \log(\varepsilon)^2 \geq C\varepsilon^{-d/k}.$$

用神经网络大小表示, 这个必要条件成为  $n_{\mathcal{A}_\varepsilon} \geq C\varepsilon^{-d/k} / \log(\varepsilon)^2$ . 正如第 7 章、特别是定理 7.11 所证明的, 忽略对数项, 网络大小  $O(\varepsilon^{-d/k})$  也足以达到误差  $\varepsilon$ . 因此, 尽管定理 7.11 的构造性证明看起来可能相当特殊, 但在深度至多对数增长这一假设下 (第 7 章的构造满足该假设), 它本质上是最优的 (参见备注 8.7).

2. 允许深度关于  $\varepsilon$  以快于对数的速度增长: 在这种情形下, 所需神经网络大小的下界得到改善. 例如, 固定具有  $L_\varepsilon$  层的  $\mathcal{A}_\varepsilon$ , 使得对某个与  $\varepsilon$  无关的固定  $W \in \mathbb{N}$ , 有  $n_{\mathcal{A}_\varepsilon} \leq WL_\varepsilon$ , 则深度的必要条件成为

$$W \log(WL_\varepsilon) L_\varepsilon^2 + WL_\varepsilon^3 \geq C\varepsilon^{-d/k},$$

从而  $L_\varepsilon \gtrsim \varepsilon^{-d/(3k)}$ .

还要补充的是, 对任意深度, 定理 14.28 中的 VC 维上界可以改进为  $n_{\mathcal{A}}^2$ , 见文献 [8, 定理 8.6]; 利用这一点, 可把刚建立的下界改进为  $L_\varepsilon \gtrsim \varepsilon^{-d/(2k)}$ .

对固定宽度, 这对应于大小为  $O(\varepsilon^{-d/(2k)})$  的神经网络, 意味着定理 7.11 所证收敛率的两倍. 事实上, 神经网络按网络大小确实可以达到这一速率 [334]. 然而, 由定理 8.4, 这只能通过不连续的权重赋值实现. 因此, 不存在达到这一速率的稳定训练算法, 这里的稳定是指连续依赖于数据.

总之, 为了对所有满足  $\|f\|_{C^k([0,1]^d)} \leq 1$  的  $f \in C^k([0,1]^d)$  一致地达到误差  $\varepsilon$ , 当  $\varepsilon \rightarrow 0$  时, ReLU 神经网络的大小必须至少按  $O(\varepsilon^{-d/(2k)})$  增长; 因此, 最佳可达到收敛率为  $2k/d$ . 已经证明这一速率也可达到, 故该界是尖锐的. 达到这一速率所需的神经网络架构, 其深度增长必须快于宽度增长.

## 文献与延伸阅读

经典统计学习理论建立在 Vapnik 和 Chervonenkis 的奠基性工作 [315] 之上. 这促成了文献 [314] 中可能近似正确 (PAC) 学习模型的提出, 本章主要采用这一模型. 关于统计学习理论, 可参见文献 [71] 中简明的数学导论; 我们还推荐近期教材 [14].

由于统计学习理论已经相当成熟, 现有大量优秀的综述性著作介绍这一理论. 特别推荐文献 [202, 285, 8]. 通过覆盖数刻画学习的具体方法在文献 [8, 第 14 章] 中有广泛讨论. 本章使用的 ReLU 激活函数相关结果由文献 [274, 32] 导出. 第 14.9 节的结果概述了文献 [332, 334] 中的部分发现. 还可在其他情形下证明上界的尖锐性, 例如假设权重经过量化时 [38, 90, 236], 或者像第 8.1 节所讨论的那样, 假设逼近方案具有某种连续性时.

## 习题

- 14.30.** 设  $\mathcal{H}$  是具有固定架构的神经网络集合, 其中权重取自一个紧集. 进一步假设激活函数连续. 证明: 对每个样本  $S$ , 总存在经验风险极小化子  $h_S$ .
- 14.31.** 完成命题 14.9 的证明.
- 14.32.** 证明引理 14.12.
- 14.33.** 证明例 14.23 中  $\mathcal{H}$  的 VC 维确实为 3; 为此, 证明  $\mathcal{H}$  不能打散任意四点集.
- 14.34.** 证明

$$\mathcal{H} := \{x \mapsto \mathbf{1}_{[0, \infty)}(\sin(wx)) \mid w \in \mathbb{R}\}$$

的 VC 维是无穷的.

## 过参数化机制下的泛化

上一章讨论了通过最小化经验风险来训练深度神经网络时的泛化理论. 一个关键结论是：只要所选架构的神经网络参数数量相对于训练样本数适中，就可能实现良好的泛化. 此外，第 14.6 节表明，选择神经网络大小以平衡泛化误差与逼近误差，即使二者之和最小，通常可以期待最佳性能.




图 15.1: ImageNet 图像分类竞赛：测试集 Top-1 类别的最终得分与参数数目/训练样本数之比. 注意，所有架构的参数数目都超过训练样本数. 这些架构包括 AlexNet [167]、VGG16 [290]、GoogLeNet [299]、ResNet50/ResNet152 [128]、DenseNet121 [137]、ViT-G/14 [338]、EfficientNetB0 [301] 和 AmoebaNet [258].

令人惊讶的是，成功的神经网络架构并不一定遵循这些理论观察. 考虑图 15.1 中的神经网络架构. 它们代表了一些最著名的图像分类模型，并且都参加过 ImageNet 图像分类竞赛 [79]. 训练集由 120 万幅图像组成. 横轴表示模型性能，纵轴表示参数数目与训练集大小之比；值得注意的是，所有架构的比值都大于 1，即参数数目多于训练样本数. 对最大的模型，神经网络参数数目是训练样本数的 1000 倍.

鉴于深度学习的实际应用似乎运行在与第 14 章所分析机制显著不同的机制下，我们必须追问：这些方法为什么仍能有效工作？

### 15.1 双下降现象

深度学习在传统统计学习理论未覆盖的机制下取得成功，曾使研究者困惑了一段时间. 文献 [24] 进行了一组引人关注的实验. 实验表明，对于不能插值数据的神经网络架

构, 风险虽然遵循第 14.6 节的上界, 但风险曲线并不会像图 14.4 所暗示的那样趋于无穷. 相反, 在越过所谓的“插值阈值”后, 风险又开始下降. 这种行为称为双下降, 如图 15.2 所示.




图 15.2: 双下降现象示意图.

### 15.1.1 重新审视最小二乘回归

为了进一步理解这一现象, 考虑第 11.2 节引入的无岭核最小二乘回归. 设数据样本  $(\mathbf{x}_j, y_j)_{j=1}^m \subseteq \mathbb{R}^d \times \mathbb{R}$  由某个真实函数  $f$  生成, 即

$$y_j = f(\mathbf{x}_j) \quad \text{对 } j = 1, \dots, m. \quad (15.1.1)$$

设  $\phi_j: \mathbb{R}^d \rightarrow \mathbb{R}$  ( $j \in \mathbb{N}$ ) 是一列试探函数 (ansatz function). 对  $n \in \mathbb{N}$ , 希望用线性最小二乘把函数  $\mathbf{x} \mapsto \sum_{i=1}^n w_i \phi_i(\mathbf{x})$  拟合到数据. 为此, 引入特征映射

$$\mathbb{R}^d \ni \mathbf{x} \mapsto \phi(\mathbf{x}) := (\phi_1(\mathbf{x}), \dots, \phi_n(\mathbf{x}))^\top \in \mathbb{R}^n.$$

目标是确定使经验风险

$$\begin{aligned} \hat{\mathcal{R}}_S(\mathbf{w}) &= \frac{1}{m} \sum_{j=1}^m \left( \sum_{i=1}^n w_i \phi_i(\mathbf{x}_j) - y_j \right)^2 \\ &= \frac{1}{m} \sum_{j=1}^m (\langle \phi(\mathbf{x}_j), \mathbf{w} \rangle - y_j)^2 \end{aligned}$$

最小的系数  $\mathbf{w} \in \mathbb{R}^n$ . 令

$$\mathbf{A}_n := \begin{pmatrix} \phi_1(\mathbf{x}_1) & \dots & \phi_n(\mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ \phi_1(\mathbf{x}_m) & \dots & \phi_n(\mathbf{x}_m) \end{pmatrix} = \begin{pmatrix} \phi(\mathbf{x}_1)^\top \\ \vdots \\ \phi(\mathbf{x}_m)^\top \end{pmatrix} \in \mathbb{R}^{m \times n}, \quad (15.1.2)$$

并令  $\mathbf{y} = (y_1, \dots, y_m)^\top$ , 则

$$\hat{\mathcal{R}}_S(\mathbf{w}) = \frac{1}{m} \|\mathbf{A}_n \mathbf{w} - \mathbf{y}\|^2. \quad (15.1.3)$$

正如第 11.1–11.2 节所讨论的, 仅当  $\mathbf{A}_n$  的秩为  $n$  时, 式 (15.1.3) 才存在唯一极小化子. 对极小化子  $\mathbf{w}_n$ , 拟合函数为

$$f_n(x) := \sum_{j=1}^n w_{n,j} \phi_j(x). \quad (15.1.4)$$

我们关心  $f_n$  随  $n$  (模型的试探函数数目或参数数目) 的变化, 并区分两种情形:

- 欠参数化: 若  $n < m$ , 则参数数目  $n$  小于训练点数目  $m$ . 对最小化  $\hat{\mathcal{R}}_S$  的最小二乘问题, 这意味着条件数目  $m$  多于自由参数数目  $n$ . 因此一般不能插值数据, 并且  $\min_{\mathbf{w} \in \mathbb{R}^n} \hat{\mathcal{R}}_S(\mathbf{w}) > 0$ .
- 过参数化: 若  $n \geq m$ , 则参数数目  $n$  至少与训练点数目  $m$  一样多. 若  $\mathbf{x}_j$  和  $\phi_j$  使  $\mathbf{A}_n \in \mathbb{R}^{m \times n}$  的秩为  $m$ , 则存在  $\mathbf{w}$  使  $\hat{\mathcal{R}}_S(\mathbf{w}) = 0$ . 若  $n > m$ , 则  $\mathbf{A}_n$  必有非平凡核, 并且存在无穷多个参数选择  $\mathbf{w}$  产生零经验风险  $\hat{\mathcal{R}}_S$ . 其中一些会在式 (15.1.4) 中产生较好的预测函数  $f_n$ , 另一些则会产生较差的预测函数.




图 15.3: 从高斯过程抽取的试探函数  $\phi_1, \dots, \phi_{40}$ , 以及 Runge 函数和 18 个等距数据点.

在过参数化情形下,  $\hat{\mathcal{R}}_S$  有许多极小化子. 用于计算极小化子的训练算法决定了所得预测函数  $f_n$  的类型. 第 11 章已经论证, 对适当的初始化, 梯度下降收敛到最小范数极小化子<sup>10</sup>

$$\mathbf{w}_{n,*} = \operatorname{argmin}_{\mathbf{w} \in M} \|\mathbf{w}\| \in \mathbb{R}^n, \quad M = \{\mathbf{w} \in \mathbb{R}^n \mid \hat{\mathcal{R}}_S(\mathbf{w}) \leq \hat{\mathcal{R}}_S(\mathbf{v}) \forall \mathbf{v} \in \mathbb{R}^n\}. \quad (15.1.5)$$

### 15.1.2 一个例子

考虑一个具体例子. 图 15.3 绘出了从高斯过程中抽取的 40 个试探函数  $\phi_1, \dots, \phi_{40}$ . 此外, 该图还绘出了 Runge 函数  $f$ , 以及用作训练数据点的  $m = 18$  个等距点. 随后, 通过式 (15.1.5) 和式 (15.1.4), 用  $\operatorname{span}\{\phi_1, \dots, \phi_n\}$  中的函数进行拟合. 结果如图 15.4 所示:

- $n = 2$ : 模型只能表示  $\operatorname{span}\{\phi_1, \phi_2\}$  中的函数. 此时模型的表达能力还不足以给出  $f$  的有意义逼近.

<sup>10</sup>这里下标  $n$  强调  $\mathbf{w}_{n,*} \in \mathbb{R}^n$  的维数. 不要将此记号与第 11 章引入的岭正则化极小化子  $\mathbf{w}_{\lambda,*}$  混淆.



- $n = 15$ : 模型具有足够的表达能力, 可以捕捉  $f$  的主要特征. 由于  $n = 15 < 18 = m$ , 它还不能插值数据. 因而可以在逼近误差与泛化误差之间取得良好平衡, 这对应于第 14 章讨论的情形.
- $n = 18$ : 此时处于插值阈值. 模型能够插值数据, 并且存在唯一的  $\mathbf{w}$  使  $\hat{\mathcal{R}}_S(\mathbf{w}) = 0$ . 然而, 在数据点之间, 预测函数  $f_{18}$  的行为似乎不规则, 并表现出强烈振荡. 这称为过拟合; 根据第 14 章的分析, 这正是预期现象: 与  $n = 15$  的情形相比, 数据点处的逼近误差有所改善, 但泛化误差变得更差.
- $n = 40$ : 此时处于过参数化机制, 参数数目显著多于数据点数目. 预测函数  $f_{40}$  插值数据, 并且由于选择了  $\hat{\mathcal{R}}_S$  的一个“良好”极小化子, 即式 (15.1.5), 它似乎是迄今对  $f$  最好的整体逼近. 还要注意, 尽管拟合已经相当好, 但并不完美. 不能期待通过进一步增大  $n$  显著改善性能, 因为此时主要限制因素是可用数据量. 另见图 15.5(a).




图 15.4: 利用图 15.3 中的试探函数  $\phi_1, \dots, \phi_n$ , 通过式 (15.1.5) 和式 (15.1.4), 以不同试探函数数目  $n$  对  $m = 18$  个红色数据点进行拟合.

图 15.5(a) 给出了误差  $\|f - f_n\|_{L^2([-1,1])}$  随  $n$  的变化. 可以观察到典型的双下降曲线: 误差先下降, 随后在由红色虚线标出的插值阈值处达到峰值; 此后进入过参数化机制, 误差再次开始下降. 图 15.5(b) 给出了  $\|\mathbf{w}_{n,*}\|$ . 注意, 系数向量的 Euclidean 范数也在插值阈值处达到峰值.

需要强调的是, 收敛曲线的具体形态强烈依赖于多种因素, 例如训练点的分布和数目  $m$ 、真实函数  $f$ , 以及试探函数  $\phi_j$  的选择 (例如用于生成图 15.3(a) 中  $\phi_j$  的具体

核). 在当前设定下, 当  $n = 15 < 18 = m$  时, 对  $f$  得到了良好逼近, 这对应于逼近误差与插值误差达到平衡的机制. 然而, 如图 15.5(a) 所示, 可能很难先验地确定适当的  $n < m$ , 而且可接受的  $n$  值范围可能相当狭窄. 对过参数化情形 ( $n \gg m$ ),  $n$  的精确选择不那么关键, 这可能使算法在该机制下更加稳定. 建议读者进行类似实验并探索不同设定, 以便更深入地理解双下降现象.




图 15.5: 图 15.4 中拟合函数的  $L^2$  误差, 以及式 (15.1.5) 定义的相应系数向量  $w_{n,*}$  的 Euclidean 范数.

## 15.2 权重大小

在图 15.5 中已经看到, 系数范数  $\|w_{n,*}\|$  表现出与  $L^2$  误差相似的行为, 并在插值阈值  $n = 18$  处达到峰值. 在机器学习中, 大权重通常是不希望出现的, 因为它们与大导数或振荡行为相关. 图 15.4 中  $n = 18$  的例子清楚展示了这一点. 假设式 (15.1.1) 中的数据由一个“光滑”函数  $f$  生成, 例如  $f$  的 Lipschitz 常数适中, 则预测函数的这些大导数可能导致较差的泛化. 关于  $f$  的这种光滑性假设可能成立, 也可能不成立. 然而, 如果  $f$  不光滑, 那么仅凭有限数据精确恢复  $f$  几乎没有希望 (见第 9.2 节的讨论).

下面的结果解释了所观察到的  $\|w_{n,*}\|$  的行为.

**命题 15.1:** 假设  $x_1, \dots, x_m$  和  $(\phi_j)_{j \in \mathbb{N}}$  使式 (15.1.2) 中的  $A_n$  对所有  $n \leq m$  都具有满秩  $n$ . 给定  $y \in \mathbb{R}^m$ , 以  $w_{n,*}(y)$  表示式 (15.1.5) 中的向量. 则映射

$$n \mapsto \sup_{\|y\|=1} \|w_{n,*}(y)\| \quad \text{单调地} \quad \begin{cases} \text{递增, } n < m, \\ \text{递减, } n \geq m. \end{cases}$$

**证明:** 先考虑  $n \geq m$  的情形. 根据假设,  $A_m$  具有满秩  $m$ , 因此对所有  $n \geq m$ ,  $A_n$  的秩均为  $m$ , 见式 (15.1.2). 特别地, 存在  $w_n \in \mathbb{R}^n$  使  $A_n w_n = y$ . 固定  $y \in \mathbb{R}^m$ , 并令  $w_n$  是任意这样的向量. 则  $w_{n+1} := (w_n, 0) \in \mathbb{R}^{n+1}$  满足  $A_{n+1} w_{n+1} = y$  且  $\|w_{n+1}\| = \|w_n\|$ . 因此, 对式 (15.1.5) 定义的最小范数解, 必有  $\|w_{n+1,*}\| \leq \|w_{n,*}\|$ . 由于这对每个  $y$  都成立, 便得到  $n \geq m$  时的结论.

现在设  $n < m$ . 回顾最小范数解可以通过伪逆写成

$$w_{n,*}(y) = A_n^\dagger y,$$

见附录 B.1. 也就是说,

$$\mathbf{A}_n^\dagger = \mathbf{V}_n \begin{pmatrix} s_{n,1}^{-1} & & \\ & \ddots & \\ & & s_{n,n}^{-1} \\ & & & \mathbf{0} \end{pmatrix} \mathbf{U}_n^\top \in \mathbb{R}^{n \times m},$$

其中  $\mathbf{A}_n = \mathbf{U}_n \mathbf{\Sigma}_n \mathbf{V}_n^\top$  是  $\mathbf{A}_n$  的奇异值分解, 并且

$$\mathbf{\Sigma}_n = \begin{pmatrix} s_{n,1} & & \\ & \ddots & \\ & & s_{n,n} \\ & & & \mathbf{0} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

包含  $\mathbf{A}_n \in \mathbb{R}^{m \times n}$  按大小递减排列的奇异值  $s_{n,1} \geq \dots \geq s_{n,n} > 0$ . 由于  $\mathbf{V}_n \in \mathbb{R}^{n \times n}$  和  $\mathbf{U}_n \in \mathbb{R}^{m \times m}$  是正交矩阵, 有

$$\sup_{\|\mathbf{y}\|=1} \|\mathbf{w}_{n,*}(\mathbf{y})\| = \sup_{\|\mathbf{y}\|=1} \|\mathbf{A}_n^\dagger \mathbf{y}\| = s_{n,n}^{-1}.$$

最后,  $\mathbf{A}_n$  的最小奇异值  $s_{n,n}$  可以写成

$$s_{n,n} = \inf_{\substack{\mathbf{x} \in \mathbb{R}^n \\ \|\mathbf{x}\|=1}} \|\mathbf{A}_n \mathbf{x}\| \geq \inf_{\substack{\mathbf{x} \in \mathbb{R}^{n+1} \\ \|\mathbf{x}\|=1}} \|\mathbf{A}_{n+1} \mathbf{x}\| = s_{n+1,n+1}.$$

因此, 当  $n \leq m$  时,  $n \mapsto s_{n,n}$  单调递减. 证明完成.  $\square$

### 15.3 理论依据

现在来考察神经网络中双下降现象的一种可能解释. 文献中还有许多其他论证 (见本章文献部分), 这里给出的解释基于对文献 [20] 中思想的简化.

分析所依赖的关键假设是: 大型过参数化神经网络往往是 Lipschitz 连续的, 且 Lipschitz 常数与网络规模无关. 这是神经网络通常具有较小权重的一个推论. 为说明这一点, 考虑深度为  $d \in \mathbb{N}$ 、宽度为  $L \in \mathbb{N}$  的架构  $\mathcal{A}$  所对应的神经网络类  $\mathcal{N}(\sigma; \mathcal{A}, B)$ . 若  $\sigma$  是  $C_\sigma$ -Lipschitz 连续的, 其中  $C_\sigma \geq 1$ , 并且对某个  $c_B > 0$  有  $B \leq c_B \cdot (dC_\sigma)^{-1}$ , 则由引理 13.2,

$$\mathcal{N}(\sigma; \mathcal{A}, B) \subseteq \text{Lip}_{c_B L}(\mathbb{R}^{d_0}). \quad (15.3.1)$$

$B \leq c_B \cdot (dC_\sigma)^{-1}$  这一类假设, 即用宽度的倒数  $1/d$  缩放权重, 在实践中并非不合理: LeCun 初始化 [177] 或 He 初始化 [127] 等标准初始化方案所使用的随机权重, 其方差与各层输入维数成反比缩放. 此外, 正如第 11 章所见, 对于很宽的神经网络, 训练期间权重不会显著偏离其初始化值. 另外, 许多训练流程会对权重使用正则化项, 从而促使优化流程找到较小的权重.

我们借助第 14 章基于覆盖数的学习结果, 研究 Lipschitz 函数的泛化能力. 紧致  $d$  维 Euclidean 区域  $\Omega$  上所有  $C$ -Lipschitz 函数组成的集合  $\text{Lip}_C(\Omega)$ , 其覆盖数满足上界

$$\log(\mathcal{G}(\text{Lip}_C(\Omega), \varepsilon, L^\infty)) \leq C_{\text{cov}} \cdot \left(\frac{C}{\varepsilon}\right)^d \quad \text{对所有 } \varepsilon > 0, \quad (15.3.2)$$

其中常数  $C_{\text{cov}}$  与  $\varepsilon > 0$  无关. 证明见文献 [113, Lemma 7], 另见文献 [310].

由此可以区分两种机制:

- 标准机制: 当神经网络规模  $n_{\mathcal{A}}$  较小时, 将神经网络看作由  $n_{\mathcal{A}}$  个参数所参数化的集合. 正如前面所见, 这给出的泛化误差界随  $n_{\mathcal{A}}$  线性缩放. 只要  $n_{\mathcal{A}}$  相比样本数较小, 由定理 14.16 就可以期待良好的泛化.
- 过参数化机制: 当神经网络规模  $n_{\mathcal{A}}$  较大而权重较小时, 将神经网络看作  $\text{Lip}_C(\Omega)$  的子集, 其中  $C > 0$  是常数. 该集合的覆盖数界与参数数目  $n_{\mathcal{A}}$  无关.

在每种机制下选取两个泛化界中较好的一个, 便得到下面的结果. 回顾  $\mathcal{N}^*(\sigma; \mathcal{A}, B)$  表示  $\mathcal{N}(\sigma; \mathcal{A}, B)$  中值域包含在  $[-1, 1]$  内的所有神经网络 (见式 (14.5.2)).

**定理 15.2:** 设  $C, C_{\mathcal{L}} > 0$ , 并设  $\mathcal{L}: [-1, 1] \times [-1, 1] \rightarrow \mathbb{R}$  是  $C_{\mathcal{L}}$ -Lipschitz 的. 再设  $\mathcal{A} = (d_0, d_1, \dots, d_{L+1}) \in \mathbb{N}^{L+2}$ ,  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  是  $C_{\sigma}$ -Lipschitz 连续的, 其中  $C_{\sigma} \geq 1$ , 并且对所有  $x \in \mathbb{R}$  都有  $|\sigma(x)| \leq C_{\sigma}|x|$ ; 最后设  $B > 0$ .

则存在  $c_1, c_2 > 0$ , 使得对每个  $m \in \mathbb{N}$  以及  $[-1, 1]^{d_0} \times [-1, 1]$  上的每个分布  $\mathcal{D}$ , 关于  $S \sim \mathcal{D}^m$  以至少  $1 - \delta$  的概率, 对所有  $\Phi \in \mathcal{N}^*(\sigma; \mathcal{A}, B) \cap \text{Lip}_C([-1, 1]^{d_0})$  都有

$$|\mathcal{R}(\Phi) - \widehat{\mathcal{R}}_S(\Phi)| \leq g(\mathcal{A}, C_{\sigma}, B, m) + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}}, \quad (15.3.3)$$

其中

$$g(\mathcal{A}, C_{\sigma}, B, m) = \min \left\{ c_1 \sqrt{\frac{n_{\mathcal{A}} \log(n_{\mathcal{A}} \lceil \sqrt{m} \rceil) + Ln_{\mathcal{A}} \log(d_{\max})}{m}}, c_2 m^{-\frac{1}{2+d_0}} \right\}.$$

**证明:** 在定理 14.11 中取  $\alpha = 1/(2 + d_0)$ , 并使用式 (15.3.2), 可得以至少  $1 - \delta/2$  的概率, 对所有  $\Phi \in \text{Lip}_C([-1, 1]^{d_0})$  都有

$$\begin{aligned} |\mathcal{R}(\Phi) - \widehat{\mathcal{R}}_S(\Phi)| &\leq 4C_{\mathcal{L}} \sqrt{\frac{C_{\text{cov}}(m^{\alpha}C)^{d_0} + \log(4/\delta)}{m}} + \frac{2C_{\mathcal{L}}}{m^{\alpha}} \\ &\leq 4C_{\mathcal{L}} \sqrt{C_{\text{cov}}C^{d_0}(m^{d_0/(d_0+2)-1})} + \frac{2C_{\mathcal{L}}}{m^{\alpha}} + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}} \\ &= 4C_{\mathcal{L}} \sqrt{C_{\text{cov}}C^{d_0}(m^{-2/(d_0+2)})} + \frac{2C_{\mathcal{L}}}{m^{\alpha}} + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}} \\ &= \frac{4C_{\mathcal{L}} \sqrt{C_{\text{cov}}C^{d_0}} + 2C_{\mathcal{L}}}{m^{\alpha}} + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}}, \end{aligned}$$

其中第二个不等式使用了对所有  $x, y \geq 0$  成立的  $\sqrt{x+y} \leq \sqrt{x} + \sqrt{y}$ .

此外, 由定理 14.16, 以至少  $1 - \delta/2$  的概率, 对所有  $\Phi \in \mathcal{N}^*(\sigma; \mathcal{A}, B)$  都有

$$\begin{aligned} |\mathcal{R}(\Phi) - \widehat{\mathcal{R}}_S(\Phi)| &\leq 4C_{\mathcal{L}} \sqrt{\frac{n_{\mathcal{A}} \log(\lceil n_{\mathcal{A}} \sqrt{m} \rceil) + Ln_{\mathcal{A}} \log(\lceil 2C_{\sigma} B d_{\max} \rceil) + \log(4/\delta)}{m}} + \frac{2C_{\mathcal{L}}}{\sqrt{m}} \\ &\leq 6C_{\mathcal{L}} \sqrt{\frac{n_{\mathcal{A}} \log(\lceil n_{\mathcal{A}} \sqrt{m} \rceil) + Ln_{\mathcal{A}} \log(\lceil 2C_{\sigma} B d_{\max} \rceil)}{m}} + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}}. \end{aligned}$$

于是, 对  $\Phi \in \mathcal{N}^*(\sigma; \mathcal{A}, B) \cap \text{Lip}_C([-1, 1]^{d_0})$ , 以至少  $1 - \delta$  的概率, 两个上界中的较小者成立.  $\square$

定理 15.2 中的两种机制，分别对应  $g(\mathcal{A}, C_\sigma, B, m)$  定义中的两个最小项. 第一项随  $n_{\mathcal{A}}$  增大，而第二项为常数. 在第一种机制中，第一项较小，泛化间隙  $|\mathcal{R}(\Phi) - \widehat{\mathcal{R}}_S(\Phi)|$  随  $n_{\mathcal{A}}$  增大.

在第二种机制中，第二项较小，泛化间隙相对于  $n_{\mathcal{A}}$  保持不变. 此外，可以合理地假设经验风险  $\widehat{\mathcal{R}}_S$  会随参数数目  $n_{\mathcal{A}}$  增大而减小.

由式 (15.3.3) 可以将风险界定为

$$\mathcal{R}(\Phi) \leq \widehat{\mathcal{R}}_S + g(\mathcal{A}, C_\sigma, B, m) + 4C_{\mathcal{L}} \sqrt{\frac{\log(4/\delta)}{m}}.$$

在第二种机制中，这个上界单调递减. 在第一种机制中，它既可能减小，也可能增大. 在某些情形下，这种行为会导致一个形似图 15.2 中曲线的风险上界. 下一节将描述出现这一情形的一个具体场景.

**注 15.3:** 定理 15.2 假设神经网络是  $C$ -Lipschitz 连续的. 正如第 15.1.2 节和第 15.2 节所见，这一假设在插值阈值附近可能不成立. 因此，定理 15.2 在插值阈值附近给出的上界很可能过于乐观.  $\diamond$

## 文献与延伸阅读

关于核回归以及参数数目对权重范数影响的讨论，文献 [24] 已经给出. 文献 [197, 123] 对更复杂的试探函数系和更精确的渐近估计进行了类似分析. 第 15.3 节的结果受到文献 [20] 启发；另见文献 [217].

关于过参数化神经网络为何具有出乎意料的良好泛化能力，更多论证的详细介绍见文献 [33, 第 2 节]. 这里只简要提及另外两个研究方向. 第一，如果学习算法引入了某种鲁棒性，就可以利用它导出泛化界 [11, 330, 43, 245]. 第二，文献 [147] 推测，对于高度过参数化的神经网络，神经网络会成为第 11 章所讨论的线性核插值器. 因此，对大型神经网络，可以通过核回归研究泛化 [147, 179, 25, 183].

## 习题

**15.4.** 设  $f: [-1, 1] \rightarrow \mathbb{R}$  是连续函数, 并对某个固定的  $m \in \mathbb{N}$ , 设  $-1 \leq x_1 < \cdots < x_m \leq 1$ . 与第 15.1.2 节一样, 我们希望用最小二乘逼近来逼近  $f$ . 为此使用 Fourier 试探函数

$$b_0(x) := \frac{1}{2}, \quad b_j(x) := \begin{cases} \sin(\lceil j/2 \rceil \pi x), & j \geq 1 \text{ 为奇数}, \\ \cos(\lceil j/2 \rceil \pi x), & j \geq 1 \text{ 为偶数}. \end{cases} \quad (15.3.4)$$

对经验风险

$$\widehat{\mathcal{R}}_S(\mathbf{w}) = \frac{1}{m} \sum_{j=1}^m \left( \sum_{i=0}^n w_i b_i(x_j) - y_j \right)^2,$$

以  $\mathbf{w}_*^n \in \mathbb{R}^{n+1}$  表示  $\widehat{\mathcal{R}}_S$  的最小范数极小化子, 并令  $f_n(x) := \sum_{i=0}^n w_{*,i}^n b_i(x)$ . 证明在这种情形下, 过参数化机制中的泛化会失败: 当  $n \gg m$  充分大时,  $f_n$  未必是  $f$  的良好逼近. 当  $n \rightarrow \infty$  时,  $f_n$  收敛到什么?

**15.5.** 考虑习题 15.4 的设定. 通过重新缩放

$$\widetilde{b}_j := c_j b_j$$

来调整式 (15.3.4) 中的试探函数. 选择实数  $c_j \in \mathbb{R}$ , 使相应的最小范数最小二乘解避免习题 15.4 中遇到的现象.

提示: 为避免过拟合, 应当用大数还是小数来缩放高频所对应的试探函数?

**15.6.** 对  $d = 1$  证明式 (15.3.2).



# 鲁棒性与对抗样本

神经网络的输出对输入的微小变化究竟有多敏感？对训练后神经网络的现实观察经常表明，即使输入只发生几乎无法察觉的修改，网络预测也可能产生剧烈变化。这一耐人寻味的行为最早在图像分类语境中由文献 [300] 记录。

图 16.1 展示了这一概念。左图是一张熊猫照片，神经网络正确地将它分类为熊猫。给图像加入几乎不可察觉的少量噪声后，就得到右图中的修改图像。对人而言，两者没有可见差异，但神经网络却将扰动后的图像分类为袋熊。一幅原本被正确分类的图像在受到轻微扰动后被错误分类，这种现象称为对抗样本。

在实践中，这种行为极不可取。它表明学习算法可能不够可靠，而且会带来潜在的安全风险，因为恶意行为者可能利用这一点欺骗算法。本章将介绍对抗样本背后的基本数学原理，并研究对抗样本可能出现或不出现的一些简单条件。为简单起见，我们限于二元分类问题，但主要思想在更一般的情形下仍然成立。

## 16.1 对抗样本

先形式化对抗样本的概念。考虑为向量  $\mathbf{x} \in \mathbb{R}^d$  指派标签  $y \in \{-1, 1\}$  的问题。假设  $\mathbf{x}$  与  $y$  之间的关系由  $\mathbb{R}^d \times \{-1, 1\}$  上的分布  $\mathcal{D}$  描述。特别地，对给定的  $\mathbf{x}$ ， $-1$  和  $1$  都可能具有正概率；也就是说，标签未必是确定性的。此外，令

$$D_{\mathbf{x}} := \{\mathbf{x} \in \mathbb{R}^d \mid \exists y \text{ 使得 } (\mathbf{x}, y) \in \text{supp}(\mathcal{D})\}, \quad (16.1.1)$$

并称  $D_{\mathbf{x}}$  为**特征支集**。

在本章中，始终以

$$g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$$


|                |                                                                                     |                 |                                                                                      |     |                                                                                       |
|----------------|-------------------------------------------------------------------------------------|-----------------|--------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------|
|                |  | $+ 0.01 \times$ |  | $=$ |  |
| Human:         | Panda                                                                               |                 | Barely visible noise                                                                 |     | Still a panda                                                                         |
| NN classifier: | Panda (high confidence)                                                             |                 | Flamingo (low confidence)                                                            |     | Wombat (high confidence)                                                              |

图 16.1: 对抗样本示意图。



表示一个固定的所谓真实分类器，它满足<sup>1</sup>

$$\mathbb{P}[y = g(\mathbf{x}) \mid \mathbf{x}] \geq \mathbb{P}[y = -g(\mathbf{x}) \mid \mathbf{x}] \quad \text{对所有 } \mathbf{x} \in D_{\mathbf{x}}. \quad (16.1.2)$$

注意，我们允许  $g$  取值 0；该值应理解为一个附加标签，对应于无关或无意义的输入数据  $\mathbf{x}$ 。我们把  $g^{-1}(0)$  称为**无关类**。真实分类器  $g$  可解释为人类会如何对数据进行分类，下面的例子说明了这一点。

**例 16.1：** 我们希望判断一幅图像显示的是熊猫 ( $y = 1$ ) 还是袋熊 ( $y = -1$ )。再次考虑图 16.1，并把三幅图像分别记为  $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 。第一幅图像  $\mathbf{x}_1$  是熊猫照片。它与标签  $y$  一起可解释为从图像分布  $\mathcal{D}$  中抽取的样本  $(\mathbf{x}_1, y)$ ；也就是说， $\mathbf{x}_1 \in D_{\mathbf{x}}$  且  $g(\mathbf{x}_1) = 1$ 。第二幅图像  $\mathbf{x}_2$  显示噪声，既不是熊猫也不是袋熊，因而对应于无关数据。特别地， $\mathbf{x}_2 \in D_{\mathbf{x}}^c$  且  $g(\mathbf{x}_2) = 0$ 。第三幅（受扰动的）图像  $\mathbf{x}_3$  也属于  $D_{\mathbf{x}}^c$ ，因为它不是照片，而是  $\mathbf{x}_1$  的噪声污染版本。尽管如此，它并非无关数据，因为人类仍会把它分类为熊猫。因此  $g(\mathbf{x}_3) = 1$ 。◇

除真实分类器  $g$  外，再以

$$h: \mathbb{R}^d \rightarrow \{-1, 1\}$$

表示某个训练后的分类器。

**定义 16.2：** 设  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$  是真实分类器， $h: \mathbb{R}^d \rightarrow \{-1, 1\}$  是分类器， $\|\cdot\|_*$  是  $\mathbb{R}^d$  上的一个范数。对  $\mathbf{x} \in \mathbb{R}^d$  和  $\delta > 0$ ，当且仅当下列条件成立时，称  $\mathbf{x}' \in \mathbb{R}^d$  是  $\mathbf{x} \in \mathbb{R}^d$  的一个扰动为  $\delta$  的**对抗样本**：

1.  $\|\mathbf{x}' - \mathbf{x}\|_* \leq \delta$ ;
2.  $g(\mathbf{x})g(\mathbf{x}') > 0$ ;
3.  $h(\mathbf{x}) = g(\mathbf{x})$  且  $h(\mathbf{x}') \neq g(\mathbf{x}')$ 。

换言之，若 (i)  $\mathbf{x}$  与  $\mathbf{x}'$  的距离至多为  $\delta$ ，(ii) 按照真实分类器， $\mathbf{x}$  与  $\mathbf{x}'$  属于同一个（非无关）类，并且 (iii) 分类器  $h$  正确分类  $\mathbf{x}$ ，却错误分类  $\mathbf{x}'$ ，那么  $\mathbf{x}'$  就是  $\mathbf{x}$  的一个扰动为  $\delta$  的对抗样本。

**注 16.3：** 需要强调，真实分类器  $g$  的概念与 Bayes 风险 (14.1.1) 的极小化子有两点不同。第一，我们允许附加标签 0 对应于无关类，而生成数据的分布  $\mathcal{D}$  中并不存在这一类。第二， $g$  应当正确分类  $D_{\mathbf{x}}$  之外的点；对抗样本中出现的图像微小扰动并不是  $D_{\mathbf{x}}$  中的常规图像。尽管如此，人类分类器仍能对这些图像进行分类，而  $g$  正是对人类分类这一性质的建模。◇

## 16.2 Bayes 分类器

乍看之下，对抗样本似乎不过是一个被错误分类的样本。如果模型的泛化不佳，这类样本自然会存在。本节介绍文献 [296] 中更为细致的观点。

<sup>1</sup>更准确地说， $y \mid \mathbf{x}$  的条件分布仅关于  $\mathbf{x}$  的边缘分布几乎处处有定义。因而，只能假设式 (16.1.2) 关于  $\mathbf{x}$  的边缘分布对几乎每个  $\mathbf{x} \in D_{\mathbf{x}}$  成立。

为避免边界情形，下面假设对所有  $\mathbf{x} \in D_{\mathbf{x}}$ ,

$$\text{或者 } \mathbb{P}[y = 1 | \mathbf{x}] > \mathbb{P}[y = -1 | \mathbf{x}] \quad \text{或者} \quad \mathbb{P}[y = 1 | \mathbf{x}] < \mathbb{P}[y = -1 | \mathbf{x}], \quad (16.2.1)$$

从而式 (16.1.2) 对  $\mathbf{x} \in D_{\mathbf{x}}$  唯一确定  $g(\mathbf{x})$ . 若  $D_{\mathbf{x}} \cup g^{-1}(0) = \mathbb{R}^d$ , 则称该分布**穷尽定义域**. 这意味着每个点或者位于特征支集  $D_{\mathbf{x}}$  中, 或者属于无关类. 此外, 若

$$\mathbb{P}[h(\mathbf{x}) | \mathbf{x}] \geq \mathbb{P}[-h(\mathbf{x}) | \mathbf{x}] \quad \text{对所有 } \mathbf{x} \in D_{\mathbf{x}},$$

则称  $h$  是一个 **Bayes 分类器**. 由式 (16.1.2), 真实分类器  $g$  是 Bayes 分类器; 而式 (16.2.1) 保证, 当  $h$  是 Bayes 分类器时,  $h$  在  $D_{\mathbf{x}}$  上与  $g$  一致. 容易看出, Bayes 分类器使 Bayes 风险最小.

利用这两个概念, 现区分以下四种情形.

1. *Bayes 分类器/穷尽分布*: 若  $h$  是 Bayes 分类器且数据穷尽定义域, 则不存在对抗样本. 这是因为每个  $\mathbf{x} \in \mathbb{R}^d$  或者属于无关类, 或者被  $h$  与  $g$  以相同方式分类.
2. *Bayes 分类器/非穷尽分布*: 若  $h$  是 Bayes 分类器且分布不穷尽定义域, 则可能存在对抗样本. 尽管学习得到的分类器  $h$  在特征支集上与真实分类器  $g$  一致, 但可以以为  $D_{\mathbf{x}} \cup g^{-1}(0)$  的非空补集中的数据点构造对抗样本.
3. *非 Bayes 分类器/穷尽分布*: 集合  $D_{\mathbf{x}}$  可由四个子域覆盖:

$$\begin{aligned} C_1 &= h^{-1}(1) \cap g^{-1}(1), & F_1 &= h^{-1}(-1) \cap g^{-1}(1), \\ C_{-1} &= h^{-1}(-1) \cap g^{-1}(-1), & F_{-1} &= h^{-1}(1) \cap g^{-1}(-1). \end{aligned} \quad (16.2.2)$$

若  $\text{dist}(C_1 \cap D_{\mathbf{x}}, F_1 \cap D_{\mathbf{x}})$  或  $\text{dist}(C_{-1} \cap D_{\mathbf{x}}, F_{-1} \cap D_{\mathbf{x}})$  小于  $\delta$ , 则存在点  $\mathbf{x}, \mathbf{x}' \in D_{\mathbf{x}}$ , 使得  $\mathbf{x}'$  是  $\mathbf{x}$  的一个扰动为  $\delta$  的对抗样本. 因而, 特征支集内可能存在对抗样本. 但这并无保证. 例如, 当  $g^{-1}(0) \neq \emptyset$  时,  $D_{\mathbf{x}}$  未必连通, 见习题 16.18. 因此, 即使分类器在数据上作出了错误预测, 对抗样本也未必存在.

4. *非 Bayes 分类器/非穷尽分布*: 在这种情形下, 一切皆有可能. 数据点及其对应的对抗样本可以出现在分布的特征支集内; 也可以离开分布的特征支集, 为特征支集中的元素构造对抗样本. 下一节将给出例子.

### 16.3 仿射分类器

对于线性分类器, 文献 [300] 和文献 [111] 概述的一个简单论证表明, 图像分类问题中常见的高维输入可能是对抗样本存在的原因之一.

线性分类器是形如

$$\mathbf{x} \mapsto \text{sign}(\mathbf{w}^\top \mathbf{x}), \quad \mathbf{w}, \mathbf{x} \in \mathbb{R}^d$$

的映射. 令

$$\mathbf{x}' := \mathbf{x} - 2|\mathbf{w}^\top \mathbf{x}| \frac{\text{sign}(\mathbf{w}^\top \mathbf{x})\text{sign}(\mathbf{w})}{\|\mathbf{w}\|_1},$$

其中  $\text{sign}(\mathbf{w})$  按坐标理解. 则  $\|\mathbf{x} - \mathbf{x}'\|_\infty \leq 2|\mathbf{w}^\top \mathbf{x}|/\|\mathbf{w}\|_1$ , 并且不难看出  $\text{sign}(\mathbf{w}^\top \mathbf{x}') \neq \text{sign}(\mathbf{w}^\top \mathbf{x})$ .

对于随机选取、但可能相互依赖的高维向量  $\mathbf{w}, \mathbf{x}$ , 若  $\mathbf{w}$  在  $d-1$  维球面上均匀分布, 则以高概率有

$$\frac{|\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|_1} \leq \frac{\|\mathbf{x}\| \|\mathbf{w}\|}{\|\mathbf{w}\|_1} \ll \|\mathbf{x}\|.$$

这是因为, 对每个  $c > 0$ ,

$$\mu(\{\mathbf{w} \in \mathbb{R}^d \mid \|\mathbf{w}\|_1 > c, \|\mathbf{w}\| \leq 1\}) \rightarrow 1 \quad (d \rightarrow \infty), \quad (16.3.1)$$

其中  $\mu$  是  $d$  维 Euclidean 单位球上的均匀概率测度, 见习题 16.17. 因而, 若  $\mathbf{x}$  的 Euclidean 范数适中, 则在高维情形下,  $\mathbf{x}'$  的扰动很可能较小.

下面在  $h$  和真实分类器  $g$  都是线性分类器时, 给出对抗样本存在的一个充分条件.

**定理 16.4:** 设非零向量  $\mathbf{w}, \bar{\mathbf{w}} \in \mathbb{R}^d$ . 对  $\mathbf{x} \in \mathbb{R}^d$ , 令  $h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x})$  为分类器, 并令  $g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x})$  为真实分类器.

对每个满足  $h(\mathbf{x})g(\mathbf{x}) > 0$  的  $\mathbf{x} \in \mathbb{R}^d$ , 以及所有满足  $\varepsilon \in (0, |\mathbf{w}^\top \mathbf{x}|)$  和

$$\frac{|\bar{\mathbf{w}}^\top \mathbf{x}|}{\|\bar{\mathbf{w}}\|} > \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|} \frac{|\mathbf{w}^\top \bar{\mathbf{w}}|}{\|\mathbf{w}\| \|\bar{\mathbf{w}}\|} \quad (16.3.2)$$

的  $\varepsilon$ , 都有

$$\mathbf{x}' = \mathbf{x} - h(\mathbf{x}) \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} \mathbf{w} \quad (16.3.3)$$

是  $\mathbf{x}$  的一个扰动为  $\delta = (\varepsilon + |\mathbf{w}^\top \mathbf{x}|)/\|\mathbf{w}\|$  的对抗样本.

在给出证明之前, 先解释这一结果. 首先, 注意  $\{\mathbf{x} \in \mathbb{R}^d \mid \mathbf{w}^\top \mathbf{x} = 0\}$  是  $h$  的决策边界; 也就是说, 位于该超平面两侧的点会被  $h$  分到不同类别. 由于  $|\mathbf{w}^\top \bar{\mathbf{w}}| \leq \|\mathbf{w}\| \|\bar{\mathbf{w}}\|$ , 式 (16.3.2) 意味着, 只要

$$\frac{|\bar{\mathbf{w}}^\top \mathbf{x}|}{\|\bar{\mathbf{w}}\|} > \frac{|\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|}, \quad (16.3.4)$$

就必定存在对抗样本. 左项是  $\mathbf{x}$  关于  $g$  的决策间隔, 即  $\mathbf{x}$  到  $g$  的决策边界的距离. 类似地, 右项是  $\mathbf{x}$  关于  $h$  的决策间隔. 因此, 当  $\mathbf{x}$  关于真实分类器  $g$  的决策间隔大于其关于分类器  $h$  的决策间隔时, 对抗样本存在.

其次, 项  $(\mathbf{w}^\top \bar{\mathbf{w}})/(\|\mathbf{w}\| \|\bar{\mathbf{w}}\|)$  描述两个分类器的对齐程度. 若分类器未对齐, 即  $\mathbf{w}$  与  $\bar{\mathbf{w}}$  之间的夹角较大, 那么即使分类器的间隔大于真实分类器的间隔, 对抗样本仍然存在.

最后, 若  $|\mathbf{w}^\top \mathbf{x}| \ll \|\mathbf{w}\|$ , 则可能存在扰动较小的对抗样本. 极端情形  $\mathbf{w}^\top \mathbf{x} = 0$  表示  $\mathbf{x}$  位于  $h$  的决策边界上; 若  $|\mathbf{w}^\top \mathbf{x}| \ll \|\mathbf{w}\|$ , 则  $\mathbf{x}$  接近  $h$  的决策边界.

**定理 16.4 的证明:** 验证式 (16.3.3) 中的  $\mathbf{x}'$  满足定义 16.2 的对抗样本条件. 下面利用  $h(\mathbf{x})g(\mathbf{x}) > 0$  所蕴含的

$$g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x}) = h(\mathbf{x}) \neq 0. \quad (16.3.5)$$

首先,

$$\|\mathbf{x} - \mathbf{x}'\| = \left\| \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} \mathbf{w} \right\| = \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|} = \delta.$$

其次证明  $g(\mathbf{x})g(\mathbf{x}') > 0$ , 即  $(\bar{\mathbf{w}}^\top \mathbf{x})(\bar{\mathbf{w}}^\top \mathbf{x}')$  为正. 代入  $\mathbf{x}'$  的定义, 该项为

$$\begin{aligned} \bar{\mathbf{w}}^\top \mathbf{x} \left( \bar{\mathbf{w}}^\top \mathbf{x} - h(\mathbf{x}) \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} \bar{\mathbf{w}}^\top \mathbf{w} \right) &= |\bar{\mathbf{w}}^\top \mathbf{x}|^2 - |\bar{\mathbf{w}}^\top \mathbf{x}| \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} \bar{\mathbf{w}}^\top \mathbf{w} \\ &\geq |\bar{\mathbf{w}}^\top \mathbf{x}|^2 - |\bar{\mathbf{w}}^\top \mathbf{x}| \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} |\bar{\mathbf{w}}^\top \mathbf{w}|. \end{aligned} \quad (16.3.6)$$

这里的等式成立, 是因为由式 (16.3.5),  $h(\mathbf{x}) = g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x})$ . 将式 (16.3.6) 的右端除以由式 (16.3.5) 可知为正的数  $|\bar{\mathbf{w}}^\top \mathbf{x}| \|\bar{\mathbf{w}}\|$ , 得到

$$\frac{|\bar{\mathbf{w}}^\top \mathbf{x}|}{\|\bar{\mathbf{w}}\|} - \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|} \frac{|\bar{\mathbf{w}}^\top \mathbf{w}|}{\|\mathbf{w}\| \|\bar{\mathbf{w}}\|}. \quad (16.3.7)$$

由式 (16.3.2), 式 (16.3.7) 中的项为正.

最后验证  $0 \neq h(\mathbf{x}') \neq h(\mathbf{x})$ , 即  $(\mathbf{w}^\top \mathbf{x})(\mathbf{w}^\top \mathbf{x}') < 0$ . 确实,

$$\begin{aligned} (\mathbf{w}^\top \mathbf{x})(\mathbf{w}^\top \mathbf{x}') &= |\mathbf{w}^\top \mathbf{x}|^2 - \mathbf{w}^\top \mathbf{x} h(\mathbf{x}) \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|^2} \mathbf{w}^\top \mathbf{w} \\ &= |\mathbf{w}^\top \mathbf{x}|^2 - |\mathbf{w}^\top \mathbf{x}|(\varepsilon + |\mathbf{w}^\top \mathbf{x}|) < 0, \end{aligned}$$

其中使用了  $h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x})$ . 证明完成.  $\square$

定理 16.4 立即蕴含下面关于仿射分类器的命题.

**命题 16.5:** 设  $\mathbf{w}, \bar{\mathbf{w}} \in \mathbb{R}^d$  且  $b, \bar{b} \in \mathbb{R}$ . 对  $\mathbf{x} \in \mathbb{R}^d$ , 令  $h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x} + b)$  为分类器, 并令  $g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x} + \bar{b})$  为真实分类器.

对每个满足  $\bar{\mathbf{w}}^\top \mathbf{x} \neq 0$ 、 $h(\mathbf{x})g(\mathbf{x}) > 0$  的  $\mathbf{x} \in \mathbb{R}^d$ , 以及所有满足  $\varepsilon \in (0, |\mathbf{w}^\top \mathbf{x} + b|)$  和

$$\frac{|\bar{\mathbf{w}}^\top \mathbf{x} + \bar{b}|^2}{\|\bar{\mathbf{w}}\|^2 + \bar{b}^2} > \frac{(\varepsilon + |\mathbf{w}^\top \mathbf{x} + b|)^2}{\|\mathbf{w}\|^2 + b^2} \frac{(\mathbf{w}^\top \bar{\mathbf{w}} + b\bar{b})^2}{(\|\mathbf{w}\|^2 + b^2)(\|\bar{\mathbf{w}}\|^2 + \bar{b}^2)},$$

都有

$$\mathbf{x}' = \mathbf{x} - h(\mathbf{x}) \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x} + b|}{\|\mathbf{w}\|^2} \mathbf{w}$$

是  $\mathbf{x}$  的一个扰动为  $\delta = (\varepsilon + |\mathbf{w}^\top \mathbf{x} + b|)/\|\mathbf{w}\|$  的对抗样本.

证明留给读者, 见习题 16.19.

现在研究线性分类器的两种情形, 它们允许不同类型的对抗样本. 在下面两个例子中, 真实分类器  $g: \mathbb{R}^d \rightarrow \{-1, 1\}$  由  $g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x})$  给出, 其中  $\bar{\mathbf{w}} \in \mathbb{R}^d$  且  $\|\bar{\mathbf{w}}\| = 1$ .

第一个例子构造一个 Bayes 分类器  $h$ , 它在特征支集的补集中允许对抗样本. 这对应于第 16.2 节的情形 2.




图 16.2: 例 16.6 和例 16.7 中两类对抗样本的示意图. 在图 A) 中, 特征支集  $D_x$  对应虚线. 图中给出了分类器  $h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x})$  的决策边界  $\text{DB}_h = \{\mathbf{x} \mid \mathbf{w}^\top \mathbf{x} = 0\}$ , 以及真实分类器  $g(\mathbf{x}) = \text{sign}(\bar{\mathbf{w}}^\top \mathbf{x})$  的决策边界  $\text{DB}_g = \{\mathbf{x} \mid \bar{\mathbf{w}}^\top \mathbf{x} = 0\}$ .  $h$  和  $g$  都正确分类  $D_x$  中的每个数据点. 将一个数据点  $\mathbf{x}$  移到分布支集之外, 同时使其关于  $h$  的标签发生改变, 就产生了对抗样本  $\mathbf{x}'$ . 在图 B) 中, 数据分布具有全局支集, 但  $h$  与  $g$  不一致, 因而决策边界  $\text{DB}_h$  与  $\text{DB}_g$  不重合. 将数据点移过  $\text{DB}_h$  可以产生对抗样本, 如  $\mathbf{x}$  和  $\mathbf{x}'$  所示.

**例 16.6:** 设  $\mathcal{D}$  是集合

$$\{(\lambda \bar{\mathbf{w}}, g(\lambda \bar{\mathbf{w}})) \mid \lambda \in [-1, 1] \setminus \{0\}\} \subseteq \mathbb{R}^d \times \{-1, 1\}$$

上的均匀分布. 特征支集为

$$D_x = \{\lambda \bar{\mathbf{w}} \mid \lambda \in [-1, 1] \setminus \{0\}\} \subseteq \text{span}\{\bar{\mathbf{w}}\}.$$

接着固定  $\alpha \in (0, 1)$ , 并取某个满足  $\mathbf{v} \in \bar{\mathbf{w}}^\perp$ 、 $\|\mathbf{v}\| = 1$  的  $\mathbf{v}$ , 令  $\mathbf{w} := \alpha \bar{\mathbf{w}} + (1 - \alpha)\mathbf{v}$ , 从而  $\|\mathbf{w}\| = 1$ . 令  $h(\mathbf{x}) := \text{sign}(\mathbf{w}^\top \mathbf{x})$ . 下面说明每个  $\mathbf{x} \in D_x$  都满足定理 16.4 的假设, 因而都存在对抗样本.

注意, 对每个  $\mathbf{x} \in D_x$  都有  $h(\mathbf{x}) = g(\mathbf{x})$ , 故  $h$  是 Bayes 分类器. 固定  $\mathbf{x} \in D_x$ . 则  $|\mathbf{w}^\top \mathbf{x}| \leq \alpha |\bar{\mathbf{w}}^\top \mathbf{x}|$ , 所以式 (16.3.2) 成立. 此外, 对每个  $\varepsilon > 0$ ,

$$\delta := \frac{\varepsilon + |\mathbf{w}^\top \mathbf{x}|}{\|\mathbf{w}\|} \leq \varepsilon + \alpha.$$

因此, 当  $\varepsilon < |\mathbf{w}^\top \mathbf{x}|$  时, 由定理 16.4, 存在扰动小于  $\varepsilon + \alpha$  的对抗样本. 当  $\alpha$  很小时, 该情形如图 16.2 的上图所示.  $\diamond$

第二个例子构造一个具有全局特征支集的分布以及一个非 Bayes 分类器. 这对应于第 16.2 节的情形 4.

**例 16.7:** 设  $\mathcal{D}_x$  是  $\mathbb{R}^d$  上的一个分布, 它在  $g$  的决策边界  $\text{DB}_g = \{\mathbf{x} | \bar{\mathbf{w}}^\top \mathbf{x} = 0\}$  之外处处具有正的 Lebesgue 密度. 定义  $\mathcal{D}$  为  $X \sim \mathcal{D}_x$  时  $(X, g(X))$  的分布. 此外, 设  $\mathbf{w} \notin \{\pm \bar{\mathbf{w}}\}$ ,  $\|\mathbf{w}\| = 1$ , 并令  $h(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x})$ . 排除  $\mathbf{w} = -\bar{\mathbf{w}}$ , 因为在这种情形下,  $h$  的每个预测都是错误的, 因而不可能存在对抗样本.

由构造, 特征支集为  $D_x = \mathbb{R}^d$ . 此外,  $h^{-1}(\{-1\})$ ,  $h^{-1}(\{1\})$ ,  $g^{-1}(\{-1\})$  和  $g^{-1}(\{1\})$  都是半空间; 按式 (16.2.2) 的记号, 这意味着

$$\text{dist}(C_{\pm 1} \cap D_x, F_{\pm 1} \cap D_x) = \text{dist}(C_{\pm 1}, F_{\pm 1}) = 0.$$

因此, 对每个  $\delta > 0$ , 以正概率可以观察到一个  $\mathbf{x}$ , 它存在扰动为  $\delta$  的对抗样本.

该情形如图 16.2 的下图所示.  $\diamond$

## 16.4 ReLU 神经网络

此前我们讨论了仿射分类器. 基于 ReLU 神经网络的二元分类器是函数  $\mathbb{R}^d \ni \mathbf{x} \mapsto \text{sign}(\Phi(\mathbf{x}))$ , 其中  $\Phi$  是一个 ReLU 神经网络. 正如文献 [300] 所指出的, 仿射分类器的论证 (见命题 16.5) 可以应用于  $\Phi$  的各个仿射片, 从而证明对抗样本的存在性.

考虑一个真实分类器  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$ . 对每个  $\mathbf{x} \in \mathbb{R}^d$ , 定义  $g$  在  $\mathbf{x}$  处的几何间隔为

$$\mu_g(\mathbf{x}) := \text{dist}(\mathbf{x}, g^{-1}(\{g(\mathbf{x})\})^c), \quad (16.4.1)$$

即  $\mathbf{x}$  到与其分类不同的最近元素的距离; 如果不存在最近元素, 则取  $\mathbf{x}$  到其他类别中元素的所有距离的下确界. 此外, 记  $\mathbf{x}$  到最近相邻仿射片的距离为

$$\nu_\Phi(\mathbf{x}) := \text{dist}(\mathbf{x}, A_{\Phi, \mathbf{x}}^c), \quad (16.4.2)$$

其中  $A_{\Phi, \mathbf{x}}$  是包含  $\mathbf{x}$  且  $\Phi$  在其上为仿射函数的最大连通区域. 我们有如下定理.

**定理 16.8:** 设  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}$ , 并对  $\mathbf{x} \in \mathbb{R}^d$  令  $h(\mathbf{x}) = \text{sign}(\Phi(\mathbf{x}))$ . 以  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$  表示真实分类器. 设  $\mathbf{x} \in \mathbb{R}^d$ ,  $\varepsilon > 0$  满足  $\nu_\Phi(\mathbf{x}) > 0$ ,  $g(\mathbf{x}) \neq 0$ ,  $\nabla \Phi(\mathbf{x}) \neq 0$ , 且

$$\mu_g(\mathbf{x}), \nu_\Phi(\mathbf{x}) > \frac{\varepsilon + |\Phi(\mathbf{x})|}{\|\nabla \Phi(\mathbf{x})\|}.$$

则

$$\mathbf{x}' := \mathbf{x} - h(\mathbf{x}) \frac{\varepsilon + |\Phi(\mathbf{x})|}{\|\nabla \Phi(\mathbf{x})\|^2} \nabla \Phi(\mathbf{x})$$

是  $\mathbf{x}$  的一个扰动为  $\delta = (\varepsilon + |\Phi(\mathbf{x})|)/\|\nabla \Phi(\mathbf{x})\|$  的对抗样本.



**证明：** 我们证明  $\mathbf{x}'$  满足定义 16.2 中的性质.

由构造,  $\|\mathbf{x} - \mathbf{x}'\| \leq \delta$ . 因为  $\mu_g(\mathbf{x}) > \delta$ , 所以  $g(\mathbf{x}) = g(\mathbf{x}')$ . 此外, 由假设  $g(\mathbf{x}) \neq 0$ , 从而  $g(\mathbf{x})g(\mathbf{x}') > 0$ .

只需再证明  $h(\mathbf{x}') \neq h(\mathbf{x})$ . 因为  $\delta < \nu_\Phi(\mathbf{x})$ , 故对某个  $b \in \mathbb{R}$ , 有  $\Phi(\mathbf{x}) = \nabla\Phi(\mathbf{x})^\top \mathbf{x} + b$  以及  $\Phi(\mathbf{x}') = \nabla\Phi(\mathbf{x})^\top \mathbf{x}' + b$ . 因此

$$\begin{aligned}\Phi(\mathbf{x}) - \Phi(\mathbf{x}') &= \nabla\Phi(\mathbf{x})^\top (\mathbf{x} - \mathbf{x}') \\ &= \nabla\Phi(\mathbf{x})^\top \left( h(\mathbf{x}) \frac{\varepsilon + |\Phi(\mathbf{x})|}{\|\nabla\Phi(\mathbf{x})\|^2} \nabla\Phi(\mathbf{x}) \right) \\ &= h(\mathbf{x})(\varepsilon + |\Phi(\mathbf{x})|).\end{aligned}$$

由于  $h(\mathbf{x})|\Phi(\mathbf{x})| = \Phi(\mathbf{x})$ , 可得  $\Phi(\mathbf{x}') = -h(\mathbf{x})\varepsilon$ . 因而  $h(\mathbf{x}') = -h(\mathbf{x})$ , 证明完毕.  $\square$

**注 16.9：** 考察定理 16.8 中的关键参数, 可以理解哪些因素会促成对抗样本.

- 真实分类器的几何间隔  $\mu_g(\mathbf{x})$ : 为了使该构造可行, 我们需要与属于不同于  $\mathbf{x}$  的类别或无关类别的点保持足够远的距离.
- 到下一个仿射片的距离  $\nu_\Phi(\mathbf{x})$ : 由于我们要在与  $\mathbf{x}$  相同的仿射片内寻找对抗样本, 故该仿射片必须足够大.
- 扰动  $\delta$ : 扰动由  $(\varepsilon + |\Phi(\mathbf{x})|)/\|\nabla\Phi(\mathbf{x})\|$  给出, 它取决于 ReLU 分类器的分类间隔  $|\Phi(\mathbf{x})|$  以及该分类器对输入的敏感度  $\|\nabla\Phi(\mathbf{x})\|$ . 为使对抗样本成为可能, 我们需要  $\Phi$  的分类间隔较小, 或者  $\Phi$  对输入的敏感度较高.

$\diamond$

## 16.5 鲁棒性

我们已经说明, 在温和假设下, 对抗样本可以通过多种方式产生. 现在转而研究阻止其存在的条件.

### 16.5.1 全局 Lipschitz 正则性

前几节反复表明: 对于线性分类器  $\text{sign}(\mathbf{w}^\top \mathbf{x})$ , 较大的  $\|\mathbf{w}\|$  会促成对抗样本; 对于 ReLU 分类器  $\text{sign}(\Phi(\mathbf{x}))$ , 较大的  $\|\nabla\Phi(\mathbf{x})\|$  也有同样作用. 自然地, 这两个量分别由分类器内部函数  $\mathbf{x} \mapsto \mathbf{w}^\top \mathbf{x}$  和  $\mathbf{x} \mapsto \Phi(\mathbf{x})$  的 Lipschitz 常数控制. 因此, 早已有研究提出, 对内部函数的 Lipschitz 常数加以限制可能是抵御对抗样本的有效措施 [300].

对于一般形式  $\mathbf{x} \mapsto \text{sign}(\Phi(\mathbf{x}))$  的分类器, 我们有如下结果.

**命题 16.10：** 设  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}$  是  $C_L$ -Lipschitz 的, 其中  $C_L > 0$ , 并设  $s > 0$ . 令  $h(\mathbf{x}) = \text{sign}(\Phi(\mathbf{x}))$  为一个分类器, 令  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$  为真实分类器. 此外, 设  $\mathbf{x} \in \mathbb{R}^d$  满足

$$\Phi(\mathbf{x})g(\mathbf{x}) \geq s. \quad (16.5.1)$$

则不存在  $\mathbf{x}$  的扰动  $\delta < s/C_L$  的对抗样本.



**证明：** 设  $\mathbf{x} \in \mathbb{R}^d$  满足式 (16.5.1)，并假设  $\|\mathbf{x}' - \mathbf{x}\| \leq \delta$ .  $\Phi$  的 Lipschitz 连续性蕴含

$$|\Phi(\mathbf{x}') - \Phi(\mathbf{x})| < s.$$

因为  $|\Phi(\mathbf{x})| \geq s$ ，所以  $\Phi(\mathbf{x}')$  与  $\Phi(\mathbf{x})$  同号，这说明  $\mathbf{x}'$  不可能是  $\mathbf{x}$  的对抗样本.  $\square$

**注 16.11：** 正如引理 13.2 所示，通过限制 ReLU 神经网络权重的大小与数目以及网络层数，可以控制其 Lipschitz 常数.  $\diamond$

这类结果受到过一些批评，参见例如文献 [140]，因为对 Lipschitz 常数的假设可能过度限制神经网络的能力. 下面给出一个结果，说明在训练集满足何种假设时，存在一个既能正确分类训练集、又不允许训练集内出现对抗样本的神经网络.

**定理 16.12：** 设  $m \in \mathbb{N}$ ,  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$  为真实分类器，并且  $(\mathbf{x}_i, g(\mathbf{x}_i))_{i=1}^m \in (\mathbb{R}^d \times \{-1, 1\})^m$ . 假设

$$\sup_{i \neq j} \frac{|g(\mathbf{x}_i) - g(\mathbf{x}_j)|}{\|\mathbf{x}_i - \mathbf{x}_j\|} =: \widetilde{M} > 0.$$

则存在一个满足  $\text{depth}(\Phi) = O(\log(m))$ 、 $\text{width}(\Phi) = O(dm)$  的 ReLU 神经网络  $\Phi$ ，使得对所有  $i = 1, \dots, m$ ,

$$\text{sign}(\Phi(\mathbf{x}_i)) = g(\mathbf{x}_i),$$

且  $\mathbf{x}_i$  不存在扰动  $\delta = 1/\widetilde{M}$  的对抗样本.

**证明：** 该结果直接由定理 9.5 和命题 16.10 得出. 读者可在习题 16.20 中补全论证.  $\square$

### 16.5.2 局部正则性

命题 16.10 这类涉及全局 Lipschitz 常数的上界存在一个问题：对深度神经网络而言，这些界可能很大. 例如，引理 13.2 给出的上界为

$$\|\Phi(\mathbf{x}) - \Phi(\mathbf{x}')\|_\infty \leq C_\sigma^L \cdot (Bd_{\max})^{L+1} \|\mathbf{x} - \mathbf{x}'\|_\infty,$$

它随神经网络深度呈指数增长. 然而在实践中，该界可能过于悲观；在局部，神经网络的梯度可能显著小于其全局 Lipschitz 常数.

因此，在局部 Lipschitz 界下研究阻止对抗样本的结果是合理的. 文献 [129] 提出了这样一个结果，以及一种给出局部 Lipschitz 常数界的算法. 下面陈述适配于本书设定的定理.

**定理 16.13：** 设  $h: \mathbb{R}^d \rightarrow \{-1, 1\}$  是形如  $h(\mathbf{x}) = \text{sign}(\Phi(\mathbf{x}))$  的分类器， $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$  是真实分类器. 设  $\mathbf{x} \in \mathbb{R}^d$  满足  $g(\mathbf{x}) \neq 0$ ，并令

$$\alpha := \max_{R>0} \min \left\{ \Phi(\mathbf{x})g(\mathbf{x}) / \sup_{\substack{\|\mathbf{y}-\mathbf{x}\|_\infty \leq R \\ \mathbf{y} \neq \mathbf{x}}} \frac{|\Phi(\mathbf{y}) - \Phi(\mathbf{x})|}{\|\mathbf{x} - \mathbf{y}\|_\infty}, R \right\}, \quad (16.5.2)$$

其中，当上确界为零时，将该最小值理解为  $R$ . 则  $\mathbf{x}$  不存在扰动  $\delta < \alpha$  的对抗样本.

**证明：** 设  $\mathbf{x} \in \mathbb{R}^d$  如定理所述. 反设对于满足式 (16.5.2) 的某个  $0 < \delta < \alpha$ , 存在  $\mathbf{x}$  的扰动  $\delta$  的对抗样本  $\mathbf{x}'$ .

如果式 (16.5.2) 中的上确界为零, 则  $\Phi$  在以  $\mathbf{x}$  为中心、半径为  $R$  的球上为常数. 特别地, 当  $\|\mathbf{x}' - \mathbf{x}\| \leq \delta < R$  时, 有  $h(\mathbf{x}') = h(\mathbf{x})$ , 故  $\mathbf{x}'$  不可能对抗样本.

现在假设式 (16.5.2) 中的上确界不为零. 由式 (16.5.2), 当  $\delta < R$  时有

$$\delta < \Phi(\mathbf{x})g(\mathbf{x}) / \sup_{\substack{\|\mathbf{y}-\mathbf{x}\|_\infty \leq R \\ \mathbf{y} \neq \mathbf{x}}} \frac{|\Phi(\mathbf{y}) - \Phi(\mathbf{x})|}{\|\mathbf{x} - \mathbf{y}\|_\infty}. \quad (16.5.3)$$

此外,

$$\begin{aligned} |\Phi(\mathbf{x}') - \Phi(\mathbf{x})| &\leq \sup_{\substack{\|\mathbf{y}-\mathbf{x}\|_\infty \leq R \\ \mathbf{y} \neq \mathbf{x}}} \frac{|\Phi(\mathbf{y}) - \Phi(\mathbf{x})|}{\|\mathbf{x} - \mathbf{y}\|_\infty} \|\mathbf{x} - \mathbf{x}'\|_\infty \\ &\leq \sup_{\substack{\|\mathbf{y}-\mathbf{x}\|_\infty \leq R \\ \mathbf{y} \neq \mathbf{x}}} \frac{|\Phi(\mathbf{y}) - \Phi(\mathbf{x})|}{\|\mathbf{x} - \mathbf{y}\|_\infty} \delta < \Phi(\mathbf{x})g(\mathbf{x}), \end{aligned}$$

其中最后一行使用了式 (16.5.3). 因而

$$\begin{aligned} g(\mathbf{x})\Phi(\mathbf{x}') &= g(\mathbf{x})\Phi(\mathbf{x}) + g(\mathbf{x})(\Phi(\mathbf{x}') - \Phi(\mathbf{x})) \\ &\geq g(\mathbf{x})\Phi(\mathbf{x}) - |\Phi(\mathbf{x}') - \Phi(\mathbf{x})| > 0. \end{aligned}$$

这排除了  $\mathbf{x}'$  为对抗样本的可能性. □

式 (16.5.2) 中的上确界由  $\Phi$  在  $B_R(\mathbf{x})$  上的 Lipschitz 常数控制. 因此, 定理 16.13 只依赖于  $\Phi$  的局部 Lipschitz 常数. 对该结果一个显然的批评是, 计算式 (16.5.2) 可能代价过高. 下面给出另一个结果, 其假设可以通过随后介绍的简单算法立即检验.

为陈述下面的命题, 对连续函数  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}$ 、 $\mathbf{x} \in \mathbb{R}^d$  和  $\delta > 0$ , 定义

$$z^{\delta, \max} := \max\{\Phi(\mathbf{y}) \mid \|\mathbf{y} - \mathbf{x}\|_\infty \leq \delta\}, \quad (16.5.4)$$

$$z^{\delta, \min} := \min\{\Phi(\mathbf{y}) \mid \|\mathbf{y} - \mathbf{x}\|_\infty \leq \delta\}. \quad (16.5.5)$$

**命题 16.14：** 设  $h: \mathbb{R}^d \rightarrow \{-1, 1\}$  是形如  $h(\mathbf{x}) = \text{sign}(\Phi(\mathbf{x}))$  的分类器,  $g: \mathbb{R}^d \rightarrow \{-1, 0, 1\}$ , 并设  $\mathbf{x}$  满足  $h(\mathbf{x}) = g(\mathbf{x})$ . 若  $z^{\delta, \max} z^{\delta, \min} > 0$ , 则  $\mathbf{x}$  不存在扰动  $\delta$  的对抗样本.

**证明：** 证明是直接的, 因为  $z^{\delta, \max} z^{\delta, \min} > 0$  蕴含  $\mathbf{x}$  的  $\delta$ -邻域中所有点都被分类为同一类. □

要应用命题 16.14, 只需计算  $z^{\delta, \max}$  和  $z^{\delta, \min}$ . 事实表明, 当  $\Phi$  是神经网络时, 可以通过与  $\Phi$  的一次前向传播类似的计算来逼近这两个量. 用  $|\mathbf{A}|$  表示对矩阵  $\mathbf{A}$  的每个元素取绝对值得到的矩阵. 此外, 定义

$$\mathbf{A}^+ = (|\mathbf{A}| + \mathbf{A})/2, \quad \mathbf{A}^- = (|\mathbf{A}| - \mathbf{A})/2.$$

算法 3 背后的思想在神经网络验证领域很常见, 参见例如文献 [101, 95, 13, 321].

---

**算法 3** 对给定神经网络计算  $\Phi(\mathbf{x})$ 、 $z^{\delta, \max}$  和  $z^{\delta, \min}$

---

**输入:** 权重矩阵  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$  与偏置向量  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$ , 其中  $\ell = 0, \dots, L$  且  $d_{L+1} = 1$ ; 单调激活函数  $\sigma$ ; 输入向量  $\mathbf{x} \in \mathbb{R}^{d_0}$ ; 邻域大小  $\delta > 0$

**输出:**  $z^{\delta, \max}$  和  $z^{\delta, \min}$  的界

$$\mathbf{x}^{(0)} = \mathbf{x}$$

$$\delta^{(0), \text{up}} = \delta \mathbf{1} \in \mathbb{R}^{d_0}$$

$$\delta^{(0), \text{low}} = \delta \mathbf{1} \in \mathbb{R}^{d_0}$$

**循环**  $\ell = 0, \dots, L-1$  **执行**

$$\mathbf{x}^{(\ell+1)} = \sigma(\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} + \mathbf{b}^{(\ell)})$$

$$\delta^{(\ell+1), \text{up}} = \sigma(\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} + (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{up}} + (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{low}} + \mathbf{b}^{(\ell)}) - \mathbf{x}^{(\ell+1)}$$

$$\delta^{(\ell+1), \text{low}} = \mathbf{x}^{(\ell+1)} - \sigma(\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} - (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{low}} - (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{up}} + \mathbf{b}^{(\ell)})$$

**结束 循环**

$$\mathbf{x}^{(L+1)} = \mathbf{W}^{(L)} \mathbf{x}^{(L)} + \mathbf{b}^{(L)}$$

$$\delta^{(L+1), \text{up}} = (\mathbf{W}^{(L)})^+ \delta^{(L), \text{up}} + (\mathbf{W}^{(L)})^- \delta^{(L), \text{low}}$$

$$\delta^{(L+1), \text{low}} = (\mathbf{W}^{(L)})^+ \delta^{(L), \text{low}} + (\mathbf{W}^{(L)})^- \delta^{(L), \text{up}}$$

$$\mathbf{return} \ \mathbf{x}^{(L+1)}, \ \mathbf{x}^{(L+1)} + \delta^{(L+1), \text{up}}, \ \mathbf{x}^{(L+1)} - \delta^{(L+1), \text{low}}$$


---

**注 16.15:** 除常数因子外, 算法 3 与一次前向传播具有相同的计算复杂度; 另见算法 1. 此外, 与通过  $\Phi$  的权重估计其全局 Lipschitz 常数所得的上界不同, 算法 3 给出的上界包含了激活函数  $\sigma$  的作用. 例如, 当  $\sigma$  为 ReLU 时, 常会出现  $\delta^{(\ell), \text{up}}$  或  $\delta^{(\ell), \text{low}}$  中许多元素为 0 的情形. 如果  $\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} + \mathbf{b}^{(\ell)}$  的某个元素非正, 则可以保证  $\delta^{(\ell), \text{low}}$  中对应的元素为零. 类似地, 如果  $\mathbf{W}^{(\ell)}$  只有很少的正元素, 则  $\delta^{(\ell), \text{up}}$  中的大多数元素都不会传播到  $\delta^{(\ell+1), \text{up}}$ .  $\diamond$

下面证明算法 3 确实给出了合理的输出.

**命题 16.16:** 设  $\Phi$  是一个神经网络, 其权重矩阵为  $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}$ 、偏置向量为  $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}}$ , 其中  $\ell = 0, \dots, L$ , 激活函数  $\sigma$  单调递增. 设  $\mathbf{x} \in \mathbb{R}^d$ . 则算法 3 的输出满足

$$\mathbf{x}^{L+1} + \delta^{(L+1), \text{up}} > z^{\delta, \max}, \quad \mathbf{x}^{L+1} - \delta^{(L+1), \text{low}} < z^{\delta, \min}.$$

**证明:** 固定满足  $\|\mathbf{y} - \mathbf{x}\|_\infty \leq \delta$  的  $\mathbf{y}, \mathbf{x} \in \mathbb{R}^d$ , 并令  $\mathbf{y}^{(\ell)}, \mathbf{x}^{(\ell)}$  ( $\ell = 0, \dots, L+1$ ) 分别为将算法 3 应用于  $\mathbf{y}, \mathbf{x}$  所得的量. 再令  $\delta^{\ell, \text{up}}, \delta^{\ell, \text{low}}$  ( $\ell = 0, \dots, L+1$ ) 为算法 3 应用于  $\mathbf{x}$  所得的量. 我们将对  $\ell = 0, \dots, L+1$  归纳证明

$$\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)} \leq \delta^{\ell, \text{up}} \quad \text{且} \quad \mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)} \leq \delta^{\ell, \text{low}}, \quad (16.5.6)$$

其中向量不等式按元素理解. 由于  $\mathbf{y}$  任意, 这便证明了结论.

$\ell = 0$  的情形直接由  $\|\mathbf{y} - \mathbf{x}\|_\infty \leq \delta$  得出. 现假设结论对  $\ell < L$  已成立. 有

$$\begin{aligned} \mathbf{y}^{(\ell+1)} - \mathbf{x}^{(\ell+1)} - \delta^{\ell+1, \text{up}} &= \sigma(\mathbf{W}^{(\ell)} \mathbf{y}^{(\ell)} + \mathbf{b}^{(\ell)}) \\ &\quad - \sigma(\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} + (\mathbf{W}^{(\ell)})^+ \delta^{\ell, \text{up}} + (\mathbf{W}^{(\ell)})^- \delta^{\ell, \text{low}} + \mathbf{b}^{(\ell)}). \end{aligned}$$

$\sigma$  的单调性表明, 只要

$$\mathbf{W}^{(\ell)} \mathbf{y}^{(\ell)} \leq \mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} + (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{up}} + (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{low}}, \quad (16.5.7)$$

就有  $\mathbf{y}^{(\ell+1)} - \mathbf{x}^{(\ell+1)} \leq \delta^{\ell+1, \text{up}}$ . 为证明式 (16.5.7), 注意到

$$\begin{aligned} \mathbf{W}^{(\ell)}(\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)}) &= (\mathbf{W}^{(\ell)})^+(\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)}) - (\mathbf{W}^{(\ell)})^-(\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)}) \\ &= (\mathbf{W}^{(\ell)})^+(\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)}) + (\mathbf{W}^{(\ell)})^-(\mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)}) \\ &\leq (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{up}} + (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{low}}, \end{aligned}$$

其中最后一行使用了归纳假设. 这证明了式 (16.5.6) 中的第一个估计.

类似地,

$$\begin{aligned} \mathbf{x}^{(\ell+1)} - \mathbf{y}^{(\ell+1)} &= \delta^{\ell+1, \text{low}} \\ &= \sigma(\mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} - (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{low}} - (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{up}} + \mathbf{b}^{(\ell)}) - \sigma(\mathbf{W}^{(\ell)} \mathbf{y}^{(\ell)} + \mathbf{b}^{(\ell)}). \end{aligned}$$

因此, 只要

$$\mathbf{W}^{(\ell)} \mathbf{y}^{(\ell)} \geq \mathbf{W}^{(\ell)} \mathbf{x}^{(\ell)} - (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{low}} - (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{up}}, \quad (16.5.8)$$

就有  $\mathbf{x}^{(\ell+1)} - \mathbf{y}^{(\ell+1)} \leq \delta^{\ell+1, \text{low}}$ . 为证明式 (16.5.8), 注意到

$$\begin{aligned} \mathbf{W}^{(\ell)}(\mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)}) &= (\mathbf{W}^{(\ell)})^+(\mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)}) - (\mathbf{W}^{(\ell)})^-(\mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)}) \\ &= (\mathbf{W}^{(\ell)})^+(\mathbf{x}^{(\ell)} - \mathbf{y}^{(\ell)}) + (\mathbf{W}^{(\ell)})^-(\mathbf{y}^{(\ell)} - \mathbf{x}^{(\ell)}) \\ &\leq (\mathbf{W}^{(\ell)})^+ \delta^{(\ell), \text{low}} + (\mathbf{W}^{(\ell)})^- \delta^{(\ell), \text{up}}, \end{aligned}$$

其中最后一行使用了归纳假设. 这就对所有  $\ell \leq L$  完成了式 (16.5.6) 的证明.

$\ell = L + 1$  的情形由同一论证得到, 只需以恒等映射替换  $\sigma$ .  $\square$

## 文献与延伸阅读

本章从奠基性论文 [300] 讲起, 但应当指出, 机器学习中非深度学习模型的对抗样本在更早的文献 [139] 中已有研究.

本章结果受到文献中多项成果的启发, 尽管它们未必以完全相同的形式出现. 整体设定受到文献 [300] 启发. 第 16.3 节基于数据高维性的解释最早由文献 [300] 和文献 [111] 提出. 第 16.2 节回顾的形式体系受到文献 [296] 启发. 通过局部 Lipschitz 性质得到的鲁棒性结果来自文献 [129]. 算法 3 涵盖在网络可验证性领域的相关结果中 [101, 95, 13, 321]. 关于现代方法更全面的概述, 参见综述文章 [262].

本章未讨论的重要方向包括对抗样本的可迁移性、防御机制以及其他对抗操作. 可迁移性是指一个模型的对抗样本往往也能欺骗其他模型的现象 [232, 207]. 防御机制, 即专门训练神经网络以阻止对抗样本的技术, 包括例如文献 [111] 的快速梯度符号法, 以及文献 [55] 等近期更复杂的方法. 最后, 对抗样本不仅可以通过加性扰动生成, 还可以通过图像的光滑变换生成, 见文献 [3, 328].

## 习题

**16.17.** 对给定的  $c > 0$ , 比较  $d$  维 Euclidean 单位球与半径为  $c$  的  $d$  维 1-球的体积, 从而证明式 (16.3.1).

**16.18.** 固定  $\delta > 0$ . 对满足式 (16.2.2) 中  $C_1 \cup C_{-1} = \emptyset$  的一对分类器  $h$  和  $g$ , 显然不可能存在任何对抗样本. 构造  $h$ 、 $g$  和  $\mathcal{D}$  的一个例子, 使得  $C_1, C_{-1} \neq \emptyset$ ,  $h$  不是 Bayes 分类器, 并且  $g$  不存在扰动为  $\delta$  的对抗样本.

当  $g^{-1}(0) = \emptyset$  时, 这是否仍然可能?

**16.19.** 证明命题 16.5.

提示: 重复定理 16.4 的证明. 在第一部分中, 令  $\mathbf{x}^{(\text{ext})} = (\mathbf{x}, 1)$ 、 $\mathbf{w}^{(\text{ext})} = (\mathbf{w}, b)$  以及  $\bar{\mathbf{w}}^{(\text{ext})} = (\bar{\mathbf{w}}, \bar{b})$ . 然后把  $\mathbf{x}'$  的定义代入, 证明  $h(\mathbf{x}') \neq h(\mathbf{x})$ .

**16.20.** 补全定理 16.12 的证明.

## 现代架构

截至目前，本书讨论的都是最经典的一类神经网络——前馈神经网络。然而在实践中，人们使用了多种多样的修改形式和变体。本章将讨论其中最常见的架构，辨明适合使用它们的情形，并在可能时证明直观的理论结论。

### 17.1 残差神经网络

深度架构往往优于浅层架构，这是深度学习的核心观念之一。贯穿本书，我们已经看到深度所带来的许多理论优势，尤其是表达能力方面的优势。然而在实践中，这些优势往往难以发挥，因为深度架构被证明更难训练。其中一个原因是深度架构容易出现梯度消失或梯度爆炸现象；我们已在第 2.3 节见过这一点。




图 17.1: 残差块示意图，其中激活函数为  $\sigma$ 、 $d = 6$ 、 $N = 3$ ，神经网络为  $\Phi$ 。

文献 [128] 研究了这一问题，其作者提出以**残差神经网络**作为解决方案。这一思想使训练非常深的神经网络成为可能，也使文献 [128] 成为该领域被引用最多的工作之一。其核心是引入所谓的残差块，以恒等映射补充一个通常的神经网络。

**定义 17.1:** 设  $d_0, d_1 \in \mathbb{N}$ ，且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 。**残差块**是如下形式的函数：

$$\mathbf{x} \mapsto \Psi_{\text{res}}(\mathbf{x}; \Phi) := \mathbf{x} + \Phi(\mathbf{x}),$$

其中， $\Phi$  是架构为  $(\sigma; d_0, d_1, d_0)$  的神经网络。

图 17.1 给出了残差块的示意图。若用残差块学习函数  $f$ ，则  $\Phi$  需要逼近残差  $\mathbf{x} \mapsto f(\mathbf{x}) - \mathbf{x}$ ，即需要施加于输入的加性变化。残差神经网络是多个残差块的复合。

**定义 17.2:** 设  $d_0, \dots, d_{L+1} \in \mathbb{N}$ ，且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 。**残差神经网络 (ResNet)** 是如下形式

的函数  $\Psi: \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_{L+1}}$ :

$$\Psi = \mathbf{W}^{(L+1)} (\Psi_{\text{res}}(\cdot; \Phi^{(L)})) \circ \cdots \circ (\Psi_{\text{res}}(\cdot; \Phi^{(1)})),$$

其中, 对  $\ell = 1, \dots, L$ ,  $\Phi^{(\ell)}: \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_0}$  是架构为  $(\sigma; d_0, d_\ell, d_0)$  的神经网络, 并且  $\mathbf{W}^{(L+1)} \in \mathbb{R}^{d_{L+1} \times d_0}$ . 最后一层作为这一线性映射起作用. 我们称  $L$  为残差神经网络的深度.

类似于定义 2.1, 可以把各残差层的输出定义为

$$\mathbf{x}_{\text{res}}^{(0)} := \mathbf{x}, \quad (17.1.1a)$$

$$\mathbf{x}_{\text{res}}^{(\ell)} := \mathbf{x}_{\text{res}}^{(\ell-1)} + \Phi^{(\ell)}(\mathbf{x}_{\text{res}}^{(\ell-1)}) \quad \text{对 } \ell = 1, \dots, L, \quad (17.1.1b)$$

$$\mathbf{x}_{\text{res}}^{(L+1)} := \mathbf{W}^{(L+1)} \mathbf{x}_{\text{res}}^{(L)}. \quad (17.1.1c)$$

于是  $\Psi(\mathbf{x}) = \mathbf{x}_{\text{res}}^{(L+1)}$ .

**注 17.3:** 在我们的定义中, 每个残差块的输入和输出维数都等于  $d_0$ . 使用恒等跳跃连接时, 这一假设是必要的; 不过还存在其他构造. 文献 [128] 还研究了以投影或嵌入代替恒等映射的跳跃连接, 从而允许维数发生变化. 本书不再进一步讨论这些构造, 请读者参阅文献 [128].  $\diamond$

### 17.1.1 反向传播与梯度消失

现在讨论残差神经网络的反向传播 (参见第 10.5 节). 以  $\mathbf{W}^{(\ell,1)} \in \mathbb{R}^{d_\ell \times d_0}$ 、 $\mathbf{W}^{(\ell,2)} \in \mathbb{R}^{d_0 \times d_\ell}$ 、 $\mathbf{b}^{(\ell,1)} \in \mathbb{R}^{d_\ell}$  和  $\mathbf{b}^{(\ell,2)} \in \mathbb{R}^{d_0}$  表示  $\Phi^{(\ell)}$  的权重, 使得

$$\Phi^{(\ell)}(\mathbf{z}) = \mathbf{W}^{(\ell,2)} \sigma(\mathbf{W}^{(\ell,1)} \mathbf{z} + \mathbf{b}^{(\ell,1)}) + \mathbf{b}^{(\ell,2)} \quad \text{对所有 } \mathbf{z} \in \mathbb{R}^{d_0}.$$

与前面一样, 我们把残差神经网络的所有权重, 即

$$(\mathbf{W}^{(\ell,1)}, \mathbf{W}^{(\ell,2)}, \mathbf{b}^{(\ell,1)}, \mathbf{b}^{(\ell,2)})_{\ell=1, \dots, L} \quad \text{和} \quad \mathbf{W}^{(L+1)}, \quad (17.1.2)$$

汇集为一个维数适当的向量  $\mathbf{w}$ . 此后也把定义 17.2 中的残差神经网络写作  $\Psi(\mathbf{x}, \mathbf{w})$ , 以强调其对式 (17.1.2) 中权重的依赖.

设  $\mathcal{L}: \mathbb{R}^{d_0} \times \mathbb{R}^{d_0} \rightarrow \mathbb{R}_+$  是一个 (可微) 损失函数, 并固定  $\mathbf{x} \in \mathbb{R}^{d_0}$ 、 $\mathbf{y} \in \mathbb{R}^{d_0}$ . 为简洁起见, 记

$$\mathcal{L} := \mathcal{L}(\Psi(\mathbf{x}, \mathbf{w}), \mathbf{y}) = \mathcal{L}(\mathbf{x}_{\text{res}}^{(L+1)}, \mathbf{y}).$$

目标是计算损失关于每个参数的导数, 即梯度

$$\nabla_{\mathbf{b}^{(\ell,1)}} \mathcal{L} \in \mathbb{R}^{d_\ell}, \quad \nabla_{\mathbf{b}^{(\ell,2)}} \mathcal{L} \in \mathbb{R}^{d_0}, \quad \nabla_{\mathbf{W}^{(\ell,1)}} \mathcal{L} \in \mathbb{R}^{d_\ell \times d_0}, \quad \nabla_{\mathbf{W}^{(\ell,2)}} \mathcal{L} \in \mathbb{R}^{d_0 \times d_\ell} \quad (17.1.3a)$$

对  $\ell = 1, \dots, L$ , 以及最后的

$$\nabla_{\mathbf{W}^{(L+1)}} \mathcal{L} \in \mathbb{R}^{d_{L+1} \times d_0}. \quad (17.1.3b)$$



与第 10.5 节一样，这需要高效地运用链式法则。遵循第 10.5.1 节的思想，并仿照式 (10.5.8)，引入辅助量

$$\boldsymbol{\beta}^{(\ell)} := \nabla_{\mathbf{x}_{\text{res}}^{(\ell)}} \mathcal{L} \quad \text{对所有 } \ell = 1, \dots, L+1.$$

类似于引理 10.15，这些向量可以从最外层开始递归计算。

**引理 17.4：** 成立

$$\boldsymbol{\beta}^{(L+1)} = \nabla_{\mathbf{x}_{\text{res}}^{(L+1)}} \mathcal{L}(\mathbf{x}_{\text{res}}^{(L+1)}, \mathbf{y}) \in \mathbb{R}^{d_{L+1}}, \quad (17.1.4a)$$

以及

$$\boldsymbol{\beta}^{(L)} = (\mathbf{W}^{(L+1)})^\top \boldsymbol{\beta}^{(L+1)} \in \mathbb{R}^{d_0}, \quad (17.1.4b)$$

并且，令  $\mathbf{I}_{d_0} \in \mathbb{R}^{d_0 \times d_0}$  为恒等矩阵，则

$$\boldsymbol{\beta}^{(\ell)} = \left( \mathbf{I}_{d_0} + \frac{\partial \Phi^{(\ell+1)}(\mathbf{x}_{\text{res}}^{(\ell)})}{\partial \mathbf{x}_{\text{res}}^{(\ell)}} \right)^\top \boldsymbol{\beta}^{(\ell+1)} \in \mathbb{R}^{d_0} \quad \text{对所有 } \ell = L-1, \dots, 1. \quad (17.1.4c)$$

**证明：** 式 (17.1.4a) 由定义成立。由式 (17.1.1c)，

$$\frac{\partial \mathbf{x}_{\text{res}}^{(L+1)}}{\partial \mathbf{x}_{\text{res}}^{(L)}} = \mathbf{W}^{(L+1)} \in \mathbb{R}^{d_{L+1} \times d_0},$$

故由链式法则，

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}_{\text{res}}^{(L)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{x}_{\text{res}}^{(L+1)}} \frac{\partial \mathbf{x}_{\text{res}}^{(L+1)}}{\partial \mathbf{x}_{\text{res}}^{(L)}} = (\boldsymbol{\beta}^{(L+1)})^\top \mathbf{W}^{(L+1)},$$

这就给出式 (17.1.4b)。

对  $\ell \in \{1, \dots, L-1\}$ ，由式 (17.1.1b) 有  $\mathbf{x}_{\text{res}}^{(\ell+1)} = \mathbf{x}_{\text{res}}^{(\ell)} + \Phi^{(\ell+1)}(\mathbf{x}_{\text{res}}^{(\ell)})$ 。因而

$$\frac{\partial \mathbf{x}_{\text{res}}^{(\ell+1)}}{\partial \mathbf{x}_{\text{res}}^{(\ell)}} = \mathbf{I}_{d_0} + \left( \frac{\partial \Phi^{(\ell+1)}(\mathbf{x}_{\text{res}}^{(\ell)})}{\partial \mathbf{x}_{\text{res}}^{(\ell)}} \right) \in \mathbb{R}^{d_0 \times d_0}.$$

与前面类似，链式法则随即给出式 (17.1.4c)。□

现在可以如下计算式 (17.1.3) 中的梯度。首先，由  $\mathbf{x}_{\text{res}}^{(L+1)} = \mathbf{W}^{(L+1)} \mathbf{x}_{\text{res}}^{(L)}$ ，对  $\mathcal{L} = \mathcal{L}(\mathbf{x}_{\text{res}}^{(L+1)}, \mathbf{y})$  运用链式法则，得到

$$\nabla_{\mathbf{W}^{(L+1)}} \mathcal{L} = \boldsymbol{\beta}^{(L+1)} (\mathbf{x}_{\text{res}}^{(L)})^\top \in \mathbb{R}^{d_{L+1} \times d_0}.$$

对于式 (17.1.3a) 中其余梯度，只展示关于  $\mathbf{b}^{(\ell,1)}$  的计算，因为其他项可作类似处理。利用  $\mathbf{x}_{\text{res}}^{(\ell)} = \mathbf{x}_{\text{res}}^{(\ell-1)} + \Phi^{(\ell)}(\mathbf{x}_{\text{res}}^{(\ell-1)})$  以及链式法则，对所有  $\ell = 1, \dots, L$ ，

$$\nabla_{\mathbf{b}^{(\ell,1)}} \mathcal{L} = \left( \frac{\partial \mathbf{x}_{\text{res}}^{(\ell)}}{\partial \mathbf{b}^{(\ell,1)}} \right)^\top \left( \frac{\partial \mathcal{L}}{\partial \mathbf{x}_{\text{res}}^{(\ell)}} \right)^\top = \frac{\partial \Phi^{(\ell)}(\mathbf{x}_{\text{res}}^{(\ell-1)})}{\partial \mathbf{b}^{(\ell,1)}} \boldsymbol{\beta}^{(\ell)}.$$

总之，全部计算都归结为：按照引理 17.4 所述，通过一次反向传播过程计算  $\boldsymbol{\beta}^{(\ell)}$ ；此外还要计算前馈神经网络  $\Phi^{(\ell)}$  的导数，而后者可以按照第 10.5 节所述，用通常的反向传播完成。

核心见解是，式 (17.1.4c) 能够抵消梯度消失问题。至少有以下两点原因：

- 对标准前馈神经网络（不含残差块），较小的激活函数导数会使  $\alpha^{(\ell)}$  相对于  $\alpha^{(\ell+1)}$  按该因子缩小（见引理 10.15 中的递推公式）。当深度  $L$  很大时，把这一效应反向传播到最初几层，可能使小  $\ell$  对应的  $\alpha^{(\ell)}$  小到可以忽略。由于这些因子会缩放关于网络权重的梯度（参见算法 1），梯度消失现象由此发生。

在残差神经网络中，较小的激活函数导数会削弱中间网络的导数  $\partial\Phi^{(\ell+1)}/\partial\mathbf{x}_{\text{res}}^{(\ell)}$ 。然而，由于式 (17.1.4c) 中存在恒等矩阵，一般不会因此使  $\beta^{(\ell)}$  相对于  $\beta^{(\ell+1)}$  衰减。

在极端情形下，若中间残差块  $\Phi^{(\ell)}$  为常值（即其导数为零），则由式 (17.1.4c) 得到  $\beta^{(\ell-1)} = \beta^{(\ell)}$ 。相反，若标准前馈网络第  $\ell$  层的导数为零（即式 (10.5.10) 中  $\sigma'(\bar{\mathbf{x}}^{(\ell)}) = \mathbf{0}$ ），则关于第  $1, \dots, \ell$  层全部权重的导数都消失。

- 虽然式 (17.1.4c) 仍可能使  $\|\beta^{(\ell-1)}\|$  小于  $\|\beta^{(\ell)}\|$ ，但这比标准情形更不容易发生。若没有恒等映射，Jacobian 矩阵  $\partial\Phi^{(\ell)}/\partial\mathbf{x}_{\text{res}}^{(\ell-1)}$  只需起到压缩映射的作用，就会使梯度变小。

相比之下，由于式 (17.1.4c) 中存在恒等映射，Jacobian 矩阵  $\partial\Phi^{(\ell)}/\partial\mathbf{x}_{\text{res}}^{(\ell-1)}$  需要把  $\beta^{(\ell)}$  映到接近  $-\beta^{(\ell)}$ ，才会使梯度减小。前一种运算只依赖于减小  $\beta^{(\ell)}$  的幅度；在后一种情形中，方向还必须对齐。

### 17.1.2 万能性

与标准神经网络一样，我们考察残差神经网络的万能逼近性质。回顾定理 3.9：只要激活函数不是多项式，宽度任意的浅层网络就具有万能逼近性质。因此，若不限制  $\Phi^{(1)}$  的宽度，单个残差块  $\Phi^{(1)}$  就足以证明含一个残差块的 ResNet 的万能性。然而，残差块的主要作用在于使深层而未必很宽的架构能够训练。因此，我们研究固定宽度但深度任意的 ResNet 能否达到万能性。

当激活函数为 ReLU 时，某种形式的万能性（在 Lebesgue 空间中）确实成立，而且  $\Phi^{(\ell)}$  只需宽度一，即定义 17.2 中  $d_1 = \dots = d_L = 1$ ，见文献 [186]。我们将证明一个类似结果；为简单起见，允许  $d_1 = \dots = d_L = 2$ ，并把更强结果的证明留作习题 17.28。先从一元函数情形开始。

**引理 17.5：** 设  $a_0 < a_1 < \dots < a_n$ ，且  $b_0, \dots, b_{n-1} \in \mathbb{R}$ 。则对任意  $0 < \delta < \min_i (a_{i+1} - a_i)$ ，存在满足  $d_1 = \dots = d_L = 2$  的 ReLU ResNet  $\Psi: \mathbb{R} \rightarrow \mathbb{R}$ ，使得

$$\Psi(x) \in [\min_i b_i, \max_j b_j] \quad \text{对所有 } x \in \mathbb{R}, \quad (17.1.5)$$

并且对所有  $i = 0, \dots, n-1$ ,

$$\Psi(x) = b_i \quad \text{若 } x \in [a_i + \delta, a_{i+1}]. \quad (17.1.6)$$

**证明：** 令  $c := \max_i |a_i| + \max_j |b_j|$ 。我们对  $\ell = 1, \dots, n+1$  作归纳，证明存在宽度为二的单层 ReLU 网络  $\Phi^{(\ell)}$ ，使得对所有  $x_{\text{res}}^{(0)} \in [a_0, a_n]$ ，若

$$x_{\text{res}}^{(\ell)} := x_{\text{res}}^{(\ell-1)} + \Phi^{(\ell)}(x_{\text{res}}^{(\ell-1)}),$$

则成立

1. 若  $x_{\text{res}}^{(0)} \leq a_{n-\ell+1}$ , 则  $x_{\text{res}}^{(\ell)} = x_{\text{res}}^{(0)} + c$ ;
2. 对所有  $j \in \{n-\ell+1, \dots, n-1\}$ , 若  $x_{\text{res}}^{(0)} \in [a_j + \delta, a_{j+1}]$ , 则  $x_{\text{res}}^{(\ell)} = b_j$ .

当  $\ell = n+1$  时, 这就给出满足式 (17.1.6) 的 ResNet. 最后还要截断该网络, 使其满足式 (17.1.5).

**步骤 1.** 对归纳基础  $\ell = 1$ , 令  $\Phi^{(1)}(x) := c$ ; 它可由宽度为二的单层 ReLU 网络实现. 此时  $x_{\text{res}}^{(1)} = x_{\text{res}}^{(0)} + c$  满足第 1 项, 而集合  $\{n-1+1, \dots, n-1\}$  为空, 故第 2 项成立.

对归纳步骤, 假设第 1-2 项对某个  $\ell \leq n$  成立. 令  $\Phi^{(\ell+1)}$  为由三片组成的连续分段线性函数, 满足

$$\Phi^{(\ell+1)}(x) = \begin{cases} 0, & x \leq a_{n-\ell} + c, \\ b_{n-\ell} - x, & x \geq a_{n-\ell} + c + \delta, \end{cases}$$

并在  $[a_{n-\ell} + c, a_{n-\ell} + c + \delta]$  上作唯一的连续线性延拓. 于是  $\Phi^{(\ell+1)}$  是两个 ReLU 的线性组合, 因而宽度为二. 验证两个性质:

1. 设  $x_{\text{res}}^{(0)} \leq a_{n-\ell}$ . 由归纳假设 1,  $x_{\text{res}}^{(\ell)} = x_{\text{res}}^{(0)} + c \leq a_{n-\ell} + c$ , 并且

$$x_{\text{res}}^{(\ell+1)} = x_{\text{res}}^{(\ell)} + \Phi^{(\ell+1)}(x_{\text{res}}^{(\ell)}) = x_{\text{res}}^{(\ell)} = x_{\text{res}}^{(0)} + c.$$

2. 设  $j \in \{n-\ell+1, \dots, n-1\}$ , 且  $x_{\text{res}}^{(0)} \in [a_j + \delta, a_{j+1}]$ . 由归纳假设 2,  $x_{\text{res}}^{(\ell)} = b_j \leq a_{n-\ell} + c$ , 故  $\Phi^{(\ell+1)}(x_{\text{res}}^{(\ell)}) = 0$ . 因而  $x_{\text{res}}^{(\ell+1)} = b_j$ .

再设  $x_{\text{res}}^{(0)} \in [a_{n-\ell} + \delta, a_{n-\ell+1}]$ . 由归纳假设 1,  $x_{\text{res}}^{(\ell)} = x_{\text{res}}^{(0)} + c$ . 因此  $x_{\text{res}}^{(\ell)} \geq a_{n-\ell} + c + \delta$ , 且

$$\begin{aligned} x_{\text{res}}^{(\ell+1)} &= x_{\text{res}}^{(\ell)} + \Phi^{(\ell+1)}(x_{\text{res}}^{(\ell)}) \\ &= x_{\text{res}}^{(\ell)} + b_{n-\ell} - x_{\text{res}}^{(\ell)} = b_{n-\ell}. \end{aligned}$$

图 17.2 展示了这一构造.

**步骤 2.** 为满足界 (17.1.5), 令  $b_{\min} := \min_i b_i$ 、 $b_{\max} := \max_j b_j$ , 并定义

$$\Phi^{(n+2)}(x) := \begin{cases} b_{\min} - x, & x \leq b_{\min}, \\ b_{\max} - x, & x \geq b_{\max}, \\ 0, & \text{其他情形,} \end{cases}$$

它仍是两个 ReLU 的线性组合. 显然, 不论  $x_{\text{res}}^{(n+1)}$  取何值,  $x_{\text{res}}^{(n+2)} = x_{\text{res}}^{(n+1)} + \Phi^{(n+2)}(x_{\text{res}}^{(n+1)})$  都满足式 (17.1.5). 此外, 当  $x_{\text{res}}^{(n+1)} \in [b_{\min}, b_{\max}]$  时,  $x_{\text{res}}^{(n+2)} = x_{\text{res}}^{(n+1)}$ .  $\square$

回顾: 对任意紧集  $K \subseteq \mathbb{R}$  和任意  $p \in [1, \infty)$ , 阶梯函数在  $L^p(K)$  中稠密. 由于我们能够用 ResNet 任意逼近阶梯函数, 显然, 在任意紧区间上, 残差神经网络在  $L^p([a_0, a_n])$  中稠密. 下面转向多元情形. 证明沿用文献 [186, Theorem 3.1] 的思想.




图 17.2: 引理 17.5 步骤 1 所构造的 ResNet 在不同层的输出. 虚线部分对应一段连续分段线性（但未必为线性）的连接. 后续 ResNet 块只影响蓝色阴影区域内的值.

**定理 17.6:** 设  $p \in [1, \infty)$ 、 $d \in \mathbb{N}$ , 并设  $f: [0, 1]^d \rightarrow \mathbb{R}$  连续. 则对每个  $\varepsilon > 0$ , 存在  $L \in \mathbb{N}$  以及满足  $d_0 = d$ 、 $d_1 = \dots = d_L = 2$ 、 $d_{L+1} = 1$  的 ReLU 残差神经网络  $\Psi$ , 使得

$$\int_{[0,1]^d} |\Psi(\mathbf{x}) - f(\mathbf{x})|^p d\mathbf{x} < \varepsilon.$$

**证明:** 证明思路是使用命题 3.22 中的量化技术. 为方便读者, 步骤 1 将稍作调整地重复该构造, 步骤 2 再用 ResNet 重新逼近这一构造.

**步骤 1.** 设  $n \in \mathbb{N}$ , 并对  $i = 0, \dots, n$  令  $a_i = i/n$ . 对  $\nu \in \Lambda_n := \{0, \dots, n-1\}^d$ , 令  $Q_\nu := \times_{j=1}^d [a_{\nu_j}, a_{\nu_j+1})$ , 并以  $f_\nu$  表示  $f$  在立方体  $Q_\nu$  中点处的值. 定义

$$F_n(\mathbf{x}) := \sum_{\nu \in \Lambda_n} f_\nu \cdot \mathbb{1}_{Q_\nu}(\mathbf{x}),$$

则

$$\lim_{n \rightarrow \infty} \int_{[0,1]^d} |f(\mathbf{x}) - F_n(\mathbf{x})|^p d\mathbf{x} = 0. \quad (17.1.7)$$

现在把  $F_n$  改写为函数的复合. 对每个  $\nu \in \{0, \dots, n-1\}^d$ , 赋予唯一的数

$$b_\nu := \sum_{j=1}^d \nu_j \cdot n^{j-1}.$$

注意,  $\{b_\nu \mid \nu \in \Lambda_n\} = \{0, \dots, n^d - 1\}$ . 接着定义

$$g(x) := \sum_{\nu \in \Lambda_n} f_\nu \cdot \mathbb{1}_{[b_\nu - 1/2, b_\nu + 1/2]}(x) \quad \text{对所有 } x \in \mathbb{R},$$

并对  $j = 1, \dots, d$  定义

$$h_j(x_j) := n^{j-1} \cdot \sum_{i=0}^{n-1} i \cdot \mathbb{1}_{[a_i, a_{i+1})}(x_j) \quad \text{对所有 } x_j \in \mathbb{R}.$$

于是, 对任意  $\mathbf{x} \in Q_\mu = \times_{j=1}^d [a_{\mu_j}, a_{\mu_j+1})$ ,

$$h(\mathbf{x}) := \sum_{j=1}^d h_j(x_j) = \sum_{j=1}^d \mu_j \cdot n^{j-1} = b_\mu,$$

从而

$$g \circ h(\mathbf{x}) = \sum_{\nu \in \Lambda_n} f_\nu \cdot \mathbb{1}_{[b_\nu-1/2, b_\nu+1/2]}(b_\mu) = f_\mu = F_n(\mathbf{x}).$$

**步骤 2.** 由式 (17.1.7), 只需证明  $F_n$  可以由具有定理所述性质的残差神经网络在  $L^p([0, 1]^d)$  中任意逼近. 现在构造一个模拟函数  $g \circ h$  的 ResNet.

首先, 把引理 17.5 应用于第一个坐标而保持其他坐标不变, 可得一个残差块宽度为二的 ResNet  $\Psi^{(1)}: \mathbb{R}^d \rightarrow \mathbb{R}^d$ , 使得

$$\Psi^{(1)}(\mathbf{x}) = \begin{pmatrix} \tilde{h}_1(x_1) \\ x_2 \\ \vdots \\ x_d \end{pmatrix},$$

其中

$$\tilde{h}_1(x_1) = h_1(x_1) \quad \text{对所有满足对每个 } i \text{ 均有 } |x_1 - a_i| > \delta \text{ 的 } x_1 \in [0, 1].$$

类似地, 对  $j = 2, \dots, d$  构造  $\Psi^{(j)}$ . 此外, 利用

$$x_1 + \sigma_{\text{ReLU}} \left( \sum_{j=2}^d x_j \right) - \sigma_{\text{ReLU}} \left( - \sum_{j=2}^d x_j \right) = \sum_{j=1}^d x_j$$

以及引理 17.5, 可知存在残差块宽度为二的 ResNet  $\Psi^{(d+1)}: \mathbb{R}^d \rightarrow \mathbb{R}$ , 使得

$$\Psi^{(d+1)}(\mathbf{x}) = \begin{pmatrix} \tilde{g}(\sum_{j=1}^d x_j) \\ x_2 \\ \vdots \\ x_d \end{pmatrix},$$

其中

$$\tilde{g}(x) = g(x) \quad \text{对所有 } x \in \{x \in [0, n^d - 1] \mid |x - i| < 1/4 \text{ 对某个 } i \in \mathbb{N}_0\},$$

并且对所有  $\mathbf{x} \in [0, 1]^d$  还有  $\min_\nu f_\nu \leq \tilde{g}(x) \leq \max_\nu f_\nu$ .

于是

$$\Psi^{(d)} \circ \dots \circ \Psi^{(1)}(\mathbf{x}) = \begin{pmatrix} \tilde{h}_1(x_1) \\ \vdots \\ \tilde{h}_d(x_d) \end{pmatrix},$$

且

$$\Psi(\mathbf{x}) := (1, 0, \dots, 0) \Psi^{(d+1)} \circ \dots \circ \Psi^{(1)}(\mathbf{x}) = \tilde{g} \left( \sum_{j=1}^d \tilde{h}_j(x_j) \right).$$

按构造, 该函数在集合

$$Z := \{\mathbf{x} \in [0, 1]^d \mid |x_j - a_i| > \delta \text{ 对所有 } i, j\}$$

上与  $F_n$  一致. 当  $\delta \rightarrow 0$  时,  $Z$  的体积趋于零, 而且  $|\Psi|$  一致地由  $\sup_{\mathbf{x} \in [0, 1]^d} |f(\mathbf{x})|$  从上方控制 (与  $\delta$  无关). 因此, 当  $\delta \rightarrow 0$  时,  $\int_{[0, 1]^d} |F_n(\mathbf{x}) - \Psi(\mathbf{x})|^p d\mathbf{x} \rightarrow 0$ . 由于  $\Psi$  是一个残差神经网络, 且其所有残差块的隐藏层宽度都为二, 证明完成.  $\square$

**注 17.7:** 定理 17.6 的证明中构造的残差神经网络  $\Psi$  有  $N = O(n^d)$  个参数. 对  $f \in C^{0,s}([0, 1]^d)$  和  $p \in [1, \infty)$ , 容易看出误差按  $\|f - \Psi\|_{L^p([0, 1]^d)} = O(n^{-s})$  缩放. 因此, 该证明不仅给出万能性; 对  $C^{0,s}$  函数, 与第 5.4 节类似, 还得到关于网络规模  $N$  的收敛率  $N^{-s/d}$ .

由于每个 ReLU ResNet 都对应一个标准前馈 ReLU 神经网络 (利用  $x = \sigma_{\text{ReLU}}(x) - \sigma_{\text{ReLU}}(-x)$ ), 可知在  $L^p$ 、 $p \in [1, \infty)$  中, 也可以通过固定一个足够大的宽度并增加深度, 达到定理 5.23 中的收敛率.  $\diamond$

### 17.1.3 何时应使用残差网络?

如本节所述, 残差神经网络能够实现非常深的架构. 若没有残差结构, 训练这类架构可能极具挑战性. 因此, 在需要解析非常复杂的依赖关系、并使用表达能力很强的深层架构时, 加入残差块可能非常有益. 另一方面, 如果问题较为简单, 可以用浅层神经网络解决, 那么残差连接通常并非必要.

## 17.2 卷积神经网络

本节将回顾深度学习中最常见的架构之一——卷积神经网络; 该架构由文献 [176]、[175] 引入.

为说明这一架构的动机, 先讨论特征的概念. 设  $\mathbf{x}, \mathbf{w} \in \mathbb{R}^d$ , 考虑单个神经元  $\mathbf{x} \mapsto \nu(\mathbf{x}) = \sigma(\langle \mathbf{w}, \mathbf{x} \rangle)$ , 并假设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$  单调递增; 这里以及下文中,  $\langle \cdot, \cdot \rangle$  仍表示 Euclidean 内积. 对满足  $\|\mathbf{x}\| = 1$  的输入  $\mathbf{x}$ , 若  $\mathbf{x}$  与  $\mathbf{w}$  更为对齐, 则响应  $\nu$  较大, 否则较小. 因而,  $\nu$  衡量  $\mathbf{x}$  中含有多少  $\mathbf{w}$  的成分. 例如, 令  $\mathbf{w} = (w_i)_{i=1}^d$ , 其中  $w_i = \sin(2\pi ki/d)$ , 并令  $\mathbf{x} \in \mathbb{R}^d$  为声学信号. 此时,  $\nu$  量化频率  $k$  对该信号的贡献. 在这一意义下, 每个神经元都可解释为检测数据的某个特定特征.

现在考虑一种特殊信号, 即图像  $\mathbf{X} = (X_{i,j})_{i,j=1}^d \in \mathbb{R}^{d \times d}$  (一个  $d \times d$  像素矩阵). 图 17.3 给出了三幅这样的图像. 它们彼此不同, 却具有完全相同的内容——一匹马在一棵树旁. 若目标是对图像中的对象分类, 则有用的特征应具有以下性质:

- 平移无关特征: 对图像中的大多数内容而言, 其出现位置并不重要. 例如, 图 17.3 中每幅图像都包含两个对象——一匹马和一棵树. 对分类而言, 这两个对象各自位于何处并不重要. 为将这一点形式化, 在  $d \times d$  像素图像上定义一个 (周期) 平移算子. 首先, 对  $i \in \mathbb{Z}$  令  $\bar{i} := ((i - 1) \bmod d) + 1$ , 并通过

$$X_{i,j} := X_{\bar{i},\bar{j}} \quad \text{对所有 } i, j \in \mathbb{Z} \quad (17.2.1)$$




图 17.3: 三幅马站在树旁的图像. 本图用于说明本节中的平移无关特征与局部特征.

周期延拓像素矩阵. 然后, 对  $k_1, k_2 \in \mathbb{Z}$  令

$$(T_{k_1, k_2}(\mathbf{X}))_{i,j} = X_{i-k_1, j-k_2} \quad \text{对所有 } i, j = 1, \dots, d. \quad (17.2.2)$$

这定义了平移算子  $T_{k_1, k_2}: \mathbb{R}^{d \times d} \rightarrow \mathbb{R}^{d \times d}$ . 现在可以重新表述我们对特征平移性质的观察: 若  $\mathbf{W} \in \mathbb{R}^{d \times d}$  是一个相关特征, 则对任意  $k_1, k_2 \in \mathbb{Z}$ , 我们预期  $T_{k_1, k_2}(\mathbf{W})$  也是相关特征, 反之亦然.

- 局部性: 再次考虑图 17.3. 比较这些图像可见, 只有小块区域发生平移, 而不是整幅图像平移. 事实上, 有意义的特征往往对应于局部小片. 换言之, 有意义的特征  $\mathbf{W}$  应满足  $\text{supp}(\mathbf{W})$  包含在一个较小的  $p \times p$  小片中, 其中  $p \ll d$ . 经验事实表明, 在图像中, 相邻像素的相关性最强, 像素相距越远, 相关性越弱 [176]. 此外, 从实践角度看, 尺寸较小的特征会大幅减少底层模型的参数数目, 使其计算更快、存储更容易.

为符合平移无关特征原则, 给定  $\mathbf{W} \in \mathbb{R}^{d \times d}$ , 应计算

$$\mathbf{X} \mapsto \sigma(\langle T_{k_1, k_2} \mathbf{W}, \mathbf{X} \rangle) \quad \text{对所有 } k_1, k_2 = 0, \dots, d-1,$$

等价地, 也可取  $k_1, k_2 \in \{1, \dots, d\}$ . 以  $*$  表示离散二维卷积算子, 即对  $\mathbf{X}, \mathbf{W} \in \mathbb{R}^{d \times d}$ ,

$$\mathbf{W} * \mathbf{X} = \left( \sum_{i,j=1}^d W_{k_1-i, k_2-j} X_{i,j} \right)_{k_1, k_2=1}^d.$$

利用式 (17.2.1) 中矩阵的对称延拓, 对  $k_1, k_2 \in \mathbb{Z}$  有

$$\begin{aligned} \langle T_{k_1, k_2} \mathbf{W}, \mathbf{X} \rangle &= \sum_{i,j=1}^d (T_{k_1, k_2} \mathbf{W})_{i,j} X_{i,j} \\ &= \sum_{i,j=1}^d W_{i-k_1, j-k_2} X_{i,j} \\ &= \sum_{i,j=1}^d \widetilde{W}_{k_1-i, k_2-j} X_{i,j} = (\widetilde{\mathbf{W}} * \mathbf{X})_{k_1, k_2}, \end{aligned} \quad (17.2.3)$$



其中使用了反射记号（参见式 (17.2.1)）

$$\widetilde{W}_{i,j} := W_{-i,-j} \quad \text{对所有 } i, j = 1, \dots, d. \quad (17.2.4)$$

因此， $(\sigma(\langle T_{k_1, k_2} \mathbf{W}, \mathbf{X} \rangle))_{k_1, k_2=1}^d$  可以通过一次卷积，再逐坐标应用  $\sigma$  来计算。注意， $(\sigma(\langle T_{k_1, k_2} \mathbf{W}, \cdot \rangle))_{k_1, k_2=1}^d$  是一个具有  $d^2$  个输出神经元和  $d^2$  个输入神经元的神经网络。然而，它的自由参数数目仅等于我们允许  $\mathbf{W}$  具有的自由参数数目（至多  $d^2$ ，而不是全连接前馈神经网络所需的  $O(d^4)$ ）。这一概念称为参数共享，因为计算各神经元输出时所使用的参数相同。这些观察引出下面的卷积神经网络定义。

**定义 17.8:** 设  $d, C_{\text{in}}, C_{\text{out}} \in \mathbb{N}$ ,  $\mathbf{W} \in \mathbb{R}^{d \times d \times C_{\text{in}} \times C_{\text{out}}}$ ,  $\mathbf{b} \in \mathbb{R}^{C_{\text{out}}}$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ .

定义函数  $\mathcal{C}: \mathbb{R}^{d \times d \times C_{\text{in}}} \rightarrow \mathbb{R}^{d \times d \times C_{\text{out}}}$  为

$$\mathbf{X} \mapsto \left( \sigma \left( \sum_{k=1}^{C_{\text{in}}} \mathbf{W}_{\cdot, \cdot, k, m} * \mathbf{X}_{\cdot, \cdot, k} + b_m \right) \right)_{m=1}^{C_{\text{out}}}, \quad (17.2.5)$$

其中  $\sigma$  与  $b_m \in \mathbb{R}$  的加法均逐坐标作用。称  $\mathcal{C}$  为激活函数为  $\sigma$ 、输入通道数为  $C_{\text{in}} \in \mathbb{N}$ 、输出通道数为  $C_{\text{out}} \in \mathbb{N}$  的卷积块。定义卷积块的规模为  $\text{size}(\mathcal{C}) = \|\mathbf{b}\|_0 + \sum_{k=1}^{C_{\text{in}}} \sum_{m=1}^{C_{\text{out}}} \|\mathbf{W}_{\cdot, \cdot, k, m}\|_0$ 。

在卷积块的定义中（以及下文定义的卷积神经网络中），我们只考虑二维输入。对一维输入、高维输入，乃至更一般的结构，也可以作类似构造。

通常，卷积块还会与池化层或展平层所构成的其他模块结合使用。

- **池化:** 池化层在前两个坐标方向上缩小输入  $\mathbf{X} \in \mathbb{R}^{d \times d \times C_{\text{in}}}$  的尺寸。例如，若  $s \in \mathbb{N}$  是  $d$  的一个因子，则可将  $d \times d$  个分量划分为  $(d/s)^2$  个大小为  $s \times s$  的小片。在每个小片上执行某种操作，将该小片归约为一个数；典型例子包括均值、最大值或其他聚合量。这些聚合量随后组成一个形状为  $(d/s) \times (d/s)$  的向量。
- **展平:** 将卷积神经网络与标准前馈神经网络结合通常很有用。为此，可应用展平层：它接收输入  $\mathbf{X} \in \mathbb{R}^{d \times d \times C_{\text{in}}}$ ，返回一个具有相同元素、但按适当方式排列的  $\mathbb{R}^{d^2 C_{\text{in}}}$  中的向量。

卷积神经网络是卷积块（通常使用不同的激活函数，例如恒等函数和 ReLU）、池化层以及后接常规神经网络的展平层的复合。图 17.4 给出了一个示意图。可用组件的这种灵活性，使得很难给出专门针对卷积神经网络卷积部分的精确结论。因此，下文将研究一种更为纯粹、不含池化层或展平层的卷积神经网络形式。

**定义 17.9:** 设  $L, d \in \mathbb{N}$ ,  $C_0, \dots, C_L \in \mathbb{N}$ . 对每个  $\ell = 1, \dots, L$ , 设  $\sigma_\ell: \mathbb{R} \rightarrow \mathbb{R}$ , 并设

$$\mathcal{C}^{(\ell)}: \mathbb{R}^{d \times d \times C_{\ell-1}} \rightarrow \mathbb{R}^{d \times d \times C_\ell}$$

为一个卷积块；它依赖于权重  $\mathbf{W}^{(\ell-1)} \in \mathbb{R}^{d \times d \times C_{\ell-1} \times C_\ell}$  和偏置  $\mathbf{b}^{(\ell-1)} \in \mathbb{R}^{C_\ell}$ , 并使用激活函数  $\sigma_{\ell-1}$ （参见定义 17.8）。

形如

$$\Psi = \mathcal{C}^{(L)} \circ \dots \circ \mathcal{C}^{(1)}(\mathbf{X})$$




图 17.4: 含两个卷积块  $C_1, C_2$  的卷积神经网络示意图. 随后是一个  $2 \times 2$  池化块, 它使每个坐标方向上的空间尺寸缩小为原来的一半. 接着应用展平层, 其后为一个单层神经网络.

的函数  $\Psi: \mathbb{R}^{d \times d \times C_0} \rightarrow \mathbb{R}^{d \times d \times C_L}$  称为卷积神经网络. 定义  $\Psi$  的规模为  $\text{size}(\Psi) = \sum_{\ell=1}^L \text{size}(C^{(\ell)})$ .

一个自然的问题是, 卷积神经网络与常规神经网络有何关系. 后者通常以向量为输入, 因此首先需要在  $\mathbb{R}^{d \times d \times q}$  与  $\mathbb{R}^{d^2 q}$  之间引入一个适当的同构, 称为  $\mathcal{I}_{\text{flat}}$ . 为使记号简洁, 我们省略参数  $d$  和  $q$ , 因为它们总能由上下文明确确定. 为比较这两类架构, 接下来研究: 对每个神经网络  $\Phi$ , 是否存在一个规模相当的卷积神经网络  $\Psi$ , 使得

$$\mathcal{I}_{\text{flat}} \circ \Psi \circ \mathcal{I}_{\text{flat}}^{-1} = \Phi. \quad (17.2.6)$$

**定义 17.10:** 设  $d, q_1, q_2 \in \mathbb{N}$ . 若对所有  $\mathbf{X} \in \mathbb{R}^{d \times d \times q_1}$  以及所有  $k_1, k_2 = 0, \dots, d-1$ , 函数  $f: \mathbb{R}^{d \times d \times q_1} \rightarrow \mathbb{R}^{d \times d \times q_2}$  满足

$$f\left((T_{k_1, k_2} \mathbf{X}_{\cdot, \cdot, i})_{i=1}^{q_1}\right) = (T_{k_1, k_2}(f(\mathbf{X})_{\cdot, \cdot, j}))_{j=1}^{q_2},$$

则称  $f$  在空间坐标上平移等变.

若  $f, g$  在空间坐标上平移等变, 且  $f \circ g$  有定义, 则  $f \circ g$  在空间坐标上也平移等变. 卷积算子是平移等变的 (见习题 17.29), 加上的偏置在空间坐标上为常数, 而激活函数则逐坐标作用. 所有这些运算都是平移等变的, 因此每个卷积块都在空间坐标上平移等变. 于是, 每个卷积神经网络也具有同一性质.

**命题 17.11:** 每个卷积神经网络都在空间坐标上平移等变.

这一观察回答了上述问题的一部分: 如下例所示, 存在这样的  $\Phi$ , 使得式 (17.2.6) 对任何卷积神经网络  $\Psi$  甚至都不能近似成立.

**例 17.12:** 在定义 17.10 中取  $q_1 = q_2 = 1$ , 并令

$$f: \mathbb{R}^{2 \times 2} \rightarrow \mathbb{R}^{2 \times 2},$$

$$\begin{pmatrix} X_{11} & X_{12} \\ X_{21} & X_{22} \end{pmatrix} \mapsto \begin{pmatrix} X_{11} & X_{11} \\ X_{11} & X_{11} \end{pmatrix}.$$

显然，该函数并非平移等变。令

$$\mathbf{X} := \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \quad \text{且} \quad T_{1,1}\mathbf{X} = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}.$$

对任意卷积神经网络  $\Psi: \mathbb{R}^{2 \times 2} \rightarrow \mathbb{R}^{2 \times 2}$ ，由平移等变性必有

$$T_{1,1}\Psi(\mathbf{X}) = \Psi(T_{1,1}\mathbf{X}).$$

由于  $T_{1,1} \circ T_{1,1}$  是  $\mathbb{R}^{2 \times 2}$  上的恒等映射，故

$$\Psi(\mathbf{X}) = T_{1,1}\Psi(T_{1,1}\mathbf{X}).$$

又因为

$$f(\mathbf{X}) = \mathbf{1} \in \mathbb{R}^{2 \times 2} \quad \text{且} \quad f(T_{1,1}\mathbf{X}) = \mathbf{0} \in \mathbb{R}^{2 \times 2}$$

分别为常数 1 矩阵与常数 0 矩阵，故必有

$$\|\Psi(\mathbf{X}) - f(\mathbf{X})\| = \|\Psi(\mathbf{X}) - \mathbf{1}\| \geq \frac{1}{2},$$

或者

$$\begin{aligned} \|\Psi(T_{1,1}\mathbf{X}) - f(T_{1,1}\mathbf{X})\| &= \|T_{1,1}\Psi(T_{1,1}\mathbf{X}) - T_{1,1}f(T_{1,1}\mathbf{X})\| \\ &= \|\Psi(\mathbf{X}) - \mathbf{0}\| \geq \frac{1}{2}. \end{aligned}$$

无论哪种情形，都没有卷积神经网络能够在  $[0, 1]^{2 \times 2}$  上以小于 1/2 的精度逼近  $f$ 。另一方面，对前馈神经网络而言，万能逼近性保证：在对激活函数施加温和条件后，存在一个神经网络能以任意精度逼近  $f$ ；见第 3 章。◇

接下来注意到，每个空间平移等变函数都完全由其在一个空间输出变量上的值所确定。事实上，

$$(f(\mathbf{X}))_{i,j,q} = (T_{1-i,1-j}f(\mathbf{X}))_{1,1,q} = (f(T_{-i-1,-j-1}\mathbf{X}))_{1,1,q}.$$

因此，可以把每个在空间坐标上平移等变的函数等同于一个只有一个空间输出维数的函数；也就是说，每个这样的  $f: \mathbb{R}^{d \times d \times q_1} \rightarrow \mathbb{R}^{d \times d \times q_2}$  都可以与某个  $g: \mathbb{R}^{d \times d \times q_1} \rightarrow \mathbb{R}^{q_2}$  相等同。

受此启发，现在研究如下问题：对于一个具有一维输出的神经网络  $\Phi$ ，在什么条件下存在卷积神经网络  $\Psi$ ，使得

$$(\mathcal{I}_{\text{flat}} \circ \Psi \circ \mathcal{I}_{\text{flat}}^{-1})_{1,1,1} = \Phi \tag{17.2.7}$$

成立？反过来，给定一个卷积神经网络  $\Psi$ ，在什么条件下存在式 (17.2.7) 中的  $\Phi$ ？文献 [237] 在更一般的条件下回答了这些问题，下面给出一些简化的结论。

**定理 17.13:** 设  $L, d \in \mathbb{N}$ ,  $d_0, \dots, d_{L+1} \in \mathbb{N}$ , 其中  $d^2 = d_0$  且  $d_{L+1} = 1$ , 并设  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 设  $\Phi$  是架构为  $(\sigma; d_0, \dots, d_{L+1})$  的神经网络.

则存在一个具有  $L+1$  层、通道数依次为  $1, d_1, \dots, d_L, 1$  的卷积神经网络  $\Psi$ ; 其激活函数满足: 对  $\ell = 0, \dots, L-1$  有  $\sigma_\ell = \sigma$ , 且  $\sigma_L = \text{id}$ . 此外, 式 (17.2.7) 成立, 且  $\text{size}(\Phi) = \text{size}(\Psi)$ .

**证明:** 逐块构造卷积神经网络  $\Psi$ , 并追踪其规模. 为区分  $\Phi$  与  $\Psi$ , 方便起见, 将  $\Phi$  的权重和偏置记为

$$\mathbf{V}^{(\ell)} \in \mathbb{R}^{d_{\ell+1} \times d_\ell}, \quad \mathbf{c}^{(\ell)} \in \mathbb{R}^{d_{\ell+1}} \quad \text{对所有 } \ell = 0, \dots, L.$$

**步骤 1 (第一个块).**  $\Psi$  的第一个块

$$\mathcal{C}^{(1)}: \mathbb{R}^{d \times d \times 1} \rightarrow \mathbb{R}^{d \times d \times d_1}$$

将用于模拟  $\Phi$  的第一层; 该层从  $\mathbb{R}^{d_0} = \mathbb{R}^{d^2}$  映射到  $\mathbb{R}^{d_1}$ . 具体地, 我们将定义权重和偏置

$$\mathbf{W}^{(0)} \in \mathbb{R}^{d \times d \times 1 \times d_1} \quad \text{且} \quad \mathbf{b}^{(0)} \in \mathbb{R}^{d_1},$$

使其非零元素至多有  $\|\mathbf{V}^{(0)}\|_0 + \|\mathbf{c}^{(0)}\|_0$  个, 并使相应卷积块  $\mathcal{C}^{(1)}$  复现映射  $\mathbf{x} \mapsto \sigma(\mathbf{V}^{(0)}\mathbf{x} + \mathbf{c}^{(0)}): \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_1}$ .

首先, 对  $\mathbf{V}^{(0)} \in \mathbb{R}^{d_1 \times d_0} = \mathbb{R}^{d_1 \times d^2}$  的每一行应用  $\mathcal{I}_{\text{flat}}^{-1}$ , 将其重塑为  $d \times d$  矩阵. 将所得矩阵记为  $(\mathbf{W}_k^{(0)})_{k=1}^{d_1}$ , 并利用式 (17.2.4) 中的记号, 令

$$\mathbf{W}_{\cdot, \cdot, 1, k}^{(0)} = \left( \widetilde{T_{-1, -1} \mathbf{W}_k^{(0)}} \right) \quad \text{对所有 } k = 1, \dots, d_1.$$

于是, 取  $\mathbf{X} = \mathcal{I}_{\text{flat}}^{-1}(\mathbf{x}) \in \mathbb{R}^{d \times d}$ , 由式 (17.2.3) 得

$$\begin{aligned} \left( \mathbf{W}_{\cdot, \cdot, 1, k}^{(0)} * \mathbf{X} \right)_{1,1} &= \left( \left( \widetilde{T_{-1, -1} \mathbf{W}_k^{(0)}} \right) * \mathbf{X} \right)_{1,1} \\ &= \sum_{i,j=1}^d \left( T_{-1, -1} \mathbf{W}_k^{(0)} \right)_{i-1, j-1} X_{i,j} \\ &= \sum_{i,j=1}^d (\mathbf{W}_k^{(0)})_{i,j} X_{i,j} = (\mathbf{V}^{(0)}\mathbf{x})_k. \end{aligned}$$

接着, 把第一个卷积块  $\mathcal{C}^{(1)}$  的偏置设为  $\Phi$  第一层的偏置, 即  $\mathbf{b}^{(0)} := \mathbf{c}^{(0)} \in \mathbb{R}^{d_1}$ . 于是, 由式 (17.2.5),

$$\mathcal{C}^{(1)}(\mathbf{X})_{1,1,k} = \left( \sigma(\mathbf{V}^{(0)}\mathbf{x} + \mathbf{c}^{(0)}) \right)_k$$

对  $k = 1, \dots, d_1$  成立. 按构造,  $\text{size}(\mathcal{C}_1) = \|\mathbf{V}^{(0)}\|_0 + \|\mathbf{c}^{(0)}\|_0$ .

**步骤 2 (第 2 至第  $L$  个块)**. 对  $\ell = 2, \dots, L$ , 令  $\mathbf{b}^{(\ell-1)} = \mathbf{c}^{(\ell-1)}$ , 并如下定义  $\mathbf{W}^{(\ell-1)} \in \mathbb{R}^{d \times d \times d_{\ell-1} \times d_\ell}$ , 由此构造卷积块  $\mathcal{C}^{(\ell)}$ :

$$W_{i,j,k,m}^{(\ell-1)} := \begin{cases} V_{m,k}^{(\ell-1)}, & \text{若 } i = j = d, \\ 0, & \text{其他情形.} \end{cases}$$

设  $\mathbf{X} \in \mathbb{R}^{d \times d \times d_{\ell-1}}$ . 则对  $m = 1, \dots, d_\ell$  和  $k = 1, \dots, d_{\ell-1}$ ,

$$\left( \mathbf{W}_{\cdot, \cdot, k, m}^{(\ell-1)} * \mathbf{X}_{\cdot, \cdot, k} \right)_{1,1} = V_{m,k}^{(\ell-1)} X_{1,1,k}.$$

因此, 对  $m = 1, \dots, d_\ell$ ,  $(\mathcal{C}^{(\ell)}(\mathbf{X}))_{1,1,m} = \sigma(\mathbf{V}^{(\ell-1)} \mathbf{X}_{1,1,\cdot} + \mathbf{c}^{(\ell-1)})_m$ . 而且  $\text{size}(\mathcal{C}^{(\ell)}) = \|\mathbf{V}^{(\ell-1)}\|_0 + \|\mathbf{c}^{(\ell-1)}\|_0$ .

**步骤 3 (第  $L+1$  个块)**. 完全仿照步骤 2 中的块构造  $\mathcal{C}^{(L+1)}$ , 但使用恒等函数作为激活函数. 自然有  $\text{size}(\mathcal{C}^{(L+1)}) = \|\mathbf{V}^{(L)}\|_0 + \|\mathbf{c}^{(L)}\|_0$ .

**步骤 4.** 按构造, 整个卷积神经网络  $\Psi$  满足

$$\text{size}(\Psi) = \sum_{\ell=0}^L \|\mathbf{V}^{(\ell)}\|_0 + \|\mathbf{c}^{(\ell)}\|_0 = \text{size}(\Phi).$$

此外, 式 (17.2.7) 按构造成立. 证明完成.  $\square$

按照定义, 卷积神经网络交替地对输入  $\mathbf{X} \in \mathbb{R}^{d \times d \times C_0}$  施加线性变换和逐元素非线性激活函数. 因此, 可以将其视为一个层数相同的标准前馈神经网络. 然而, 由于卷积中的权重共享 (同一组权重应用于  $d^2$  个空间位置), 写成标准形式后, 权重矩阵中的非零元素数目会增大为原来的  $d^2$  倍. 下面的定理将这一结论精确化.

**定理 17.14:** 设  $L, d \in \mathbb{N}$ , 且  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ . 设  $\Psi: \mathbb{R}^{d \times d \times C_0} \rightarrow \mathbb{R}^{d \times d \times C_L}$  是定义 17.9 所述的卷积神经网络, 它有  $L$  层, 每层都使用  $\sigma$  作为激活函数, 并且通道数满足  $C_0 = 1$  及  $C_1, \dots, C_L \in \mathbb{N}$ .

则存在一个具有  $L$  层、架构为  $(\sigma; d_0, \dots, d_L, 1)$  的神经网络  $\Phi: \mathbb{R}^{d^2} \rightarrow \mathbb{R}$ , 其中对  $j = 0, \dots, L$  有  $d_j = C_j d^2$ , 使得式 (17.2.7) 成立. 此外,  $\text{size}(\Phi) \leq d^2 \text{size}(\Psi)$ .

**证明:** 设  $\mathbf{W}^{(0)} \in \mathbb{R}^{d \times d \times C_0 \times C_1}$ , 且  $\mathbf{X} \in \mathbb{R}^{d \times d \times C_0}$ . 对每个  $m \in \{1, \dots, C_1\}$ , 存在矩阵  $\mathbf{V}_m^{(0)} \in \mathbb{R}^{d^2 \times C_0 d^2}$ , 使得

$$\mathcal{I}_{\text{flat}} \left( \sum_{k=1}^{C_0} \mathbf{W}_{\cdot, \cdot, k, m}^{(0)} * \mathbf{X}_{\cdot, \cdot, k} \right) = \mathbf{V}_m^{(0)} \mathcal{I}_{\text{flat}}(\mathbf{X}),$$

因为左侧定义了关于  $\mathbf{X}$  的线性映射. 不难看出,  $\|\mathbf{V}_m^{(0)}\|_0 \leq d^2 \|\mathbf{W}_{\cdot, \cdot, 1, m}^{(0)}\|_0$ .

定义矩阵

$$\mathbf{V}^{(0)} = \begin{pmatrix} \mathbf{V}_1^{(0)} \\ \vdots \\ \mathbf{V}_{C_1}^{(0)} \end{pmatrix} \in \mathbb{R}^{C_1 d^2 \times C_0^2 d^2},$$

以及向量  $\mathbf{c}^{(0)} = (b_1^{(0)}, b_1^{(0)}, \dots, b_2^{(0)}, \dots, b_{C_1}^{(0)}) \in \mathbb{R}^{d^2 C_1}$ ，其中每个  $b_m^{(0)}$  出现  $d^2$  次。

对向量  $\mathbf{z} \in \mathbb{R}^{d^2 C_1}$ ，以  $\mathbf{z}_{d^2[m-1, m]}$  表示与区间  $[d^2(m-1), d^2 m]$  中的指标相对应的子向量。于是

$$(\mathbf{V}^{(0)} \mathcal{I}_{\text{flat}}(\mathbf{X}) + \mathbf{c}^{(0)})_{d^2[m-1, m]} = \mathcal{I}_{\text{flat}} \left( \sum_{k=1}^{C_0} \mathbf{W}_{\cdot, \cdot, k, m}^{(0)} * \mathbf{X}_{\cdot, \cdot, k} + b_m^{(0)} \right).$$

自然有  $\|\mathbf{V}^{(0)}\|_0 \leq d^2 \sum_{k=1}^{C_0} \sum_{m=1}^{C_1} \|\mathbf{W}_{\cdot, \cdot, k, m}^{(0)}\|_0$ ，且  $\|\mathbf{c}^{(0)}\|_0 \leq d^2 \|\mathbf{b}^{(0)}\|_0$ 。在等式两侧逐分量应用  $\sigma$  后，我们便把  $\Psi$  的第一个卷积层  $\mathcal{C}^{(1)}$  的展平输出构造成了一个单层标准前馈神经网络。

利用同样的构造，卷积神经网络的每个后续层也都可转化为一个常规神经网络层（只需在上述计算中以  $C_{\ell-1}, C_\ell$  代替  $C_0, C_1$ ）。此时两个网络  $\Phi$  与  $\Psi$  由展平联系起来，并且  $\text{size}(\Phi) \leq d^2 \text{size}(\Psi)$ 。□

由定理 17.13 和定理 17.14 可见，卷积神经网络与标准前馈神经网络关系密切。只考察一个同规模卷积神经网络的第一个空间输出坐标，就可以重构一个神经网络。另一方面，要重构一个卷积神经网络，则需要一个比该卷积神经网络更大的神经网络。事实上，这一差距并非仅仅是证明方法造成的。文献 [282] 表明：在比较参数数目相同的卷积神经网络函数类与神经网络函数类时，卷积神经网络的函数类要大得多。更具体地说，它具有显著更大的 VC 维。

**注 17.15：** 使用池化后，本节的核心性质——平移等变性——将不再存在。事实上，文献 [333] 表明，根据卷积神经网络架构中所采用的池化程度，所得函数会在平移等变与平移不变之间变化。◇

### 17.2.1 何时应使用卷积神经网络？

当底层数据呈现平移无关特征，并且坐标之间的局部关系有意义时，卷积神经网络表现出色。若不满足这一条件，则所得函数对特征的平移无关性将没有意义，并可能引入不必要的额外开销。此外，如果长程依赖对模型很重要，例如在自然语言处理中，那么滤波器尺寸较小的卷积神经网络可能难以复现这类函数。再者，我们已经看到，卷积神经网络的表达能力强于其全连接对应网络。因此，在训练数据较少的情形下，它们的泛化表现会更差。

## 17.3 Transformer

上一节已经看到，卷积神经网络在刻画局部依赖方面非常有效，这是因为卷积滤波器作用于输入的小邻域。然而，卷积层并不适合捕捉长程相关性。

文献 [316] 引入的 Transformer (transformer) 提供了一种利用全局依赖的机制。在数据具有这类结构的任务中，这些模型取得了巨大成功。例如，BERT [80]、GPT-3 [49]、LLaMA [312] 和 PaLM [64] 等 Transformer 是为数百万人提供帮助的聊天机器人的基础。此外，Transformer 还是用于预测蛋白质折叠的 AlphaFold 2 [152] 的基础；其创建者于 2024 年获得了诺贝尔化学奖。



下面回顾相应的架构. Transformer 作用于向量序列. 为了理解它们, 以自然语言处理的应用为引导性例子会很有帮助. 为此, 我们首先在第 17.3.1 小节说明如何把文本映射为向量序列; 在第 17.3.2 小节介绍 Transformer 的主要构件——自注意力; 随后在第 17.3.3 小节定义一种特定类型的 Transformer; 最后在第 17.3.4 小节说明如何用 Transformer 生成文本.

本节始终使用如下方便的记号: 对于函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}^d$ , 以  $f^{\text{col}}: \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$  表示逐列应用, 即对  $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n) \in \mathbb{R}^{d \times n}$ , 有

$$f^{\text{col}}(\mathbf{X}) = [f(\mathbf{x}_1), \dots, f(\mathbf{x}_n)]. \quad (17.3.1)$$

特别地,  $f^{\text{col}}$  独立作用于每一列, 不会在各列之间混合信息.

### 17.3.1 嵌入与位置编码

自然语言处理的第一步通常是所谓的词元化: 设  $\mathcal{V}$  为词元集合, 其中的词元可以是音节、词的一部分或完整的词. 随后, 对每个  $v \in \mathcal{V}$ , 把该词元映射为嵌入向量  $\mathbf{e}_v \in \mathbb{R}^d$ . 这种嵌入应当保留语言的某些结构, 例如, 意义相近的词元所对应的嵌入向量也应具有某种相似性.

除了词元本身, 我们还希望向算法传达词元在句子中的位置信息. 例如, 考虑

The dog chased the cat.

或者

The cat chased the dog.

这两个句子由相同的词 (或词元) 组成, 但 “cat” 和 “dog” 的位置显然对句意起着关键作用. 所谓的位置编码可以存储这类信息. 一种做法是将嵌入向量与位置编码向量拼接起来. 文献 [316] 则建议把位置编码加到嵌入上. 具体而言, 对于位置  $j$  处的词元  $v \in \mathcal{V}$ , 定义位置编码向量  $\mathbf{s}_j \in \mathbb{R}^d$  为

$$s_{j,2i} = \sin\left(\frac{j}{10000^{2i/d}}\right), \quad s_{j,2i+1} = \cos\left(\frac{j}{10000^{2i/d}}\right), \quad (17.3.2)$$

并将其加到该词元的嵌入向量  $\mathbf{e}_v$  上.

这种位置编码的动机如下: 对每个嵌入维度  $2i$  或  $2i+1 \in \{1, \dots, d\}$ , 它形成波长介于  $2\pi$  与  $2\pi \cdot 10000$  之间的正弦波. 数 10000 是一个超参数; 根据最大上下文长度 (即词元的最大数目) 把它取得充分大, 便可在有限的最大上下文长度以内避免重复, 即对所有  $j \neq k$  都有  $\mathbf{s}_j \neq \mathbf{s}_k$ . 这要求波长充分大. 此外,  $\mathbf{s}_j$  与  $\mathbf{s}_k$  的内积仅依赖于距离  $j-k$ , 见习题 17.30. 这类性质是可取的, 因为自然语言中的依赖关系往往取决于词之间的相对距离, 而非绝对位置.

### 17.3.2 因果自注意力机制

设  $n \in \mathbb{N}$ , 并再次以  $d \in \mathbb{N}$  表示嵌入维数. Transformer 作用于长度为  $n$  的序列, 我们用数据矩阵  $\mathbf{X} \in \mathbb{R}^{d \times n}$  表示该序列. 在本节余下部分中, 不应把序列长度 (或上



下文长度)  $n$  理解为固定值, 而应将其视为变量; 如下文所示, 这种架构能够处理任意  $n \in \mathbb{N}$ . 这与本书第一部分讨论的前馈神经网络不同, 后者以固定长度的向量作为输入. 在自然语言语境下,  $\mathbf{X}$  的每一列都对应于第 17.3.1 小节所述的一个词的嵌入. 从数学上说, (带掩码的) 自注意力机制以矩阵  $\mathbf{X}$  为输入并返回

$$\mathbf{V}_{\text{softmax}^{\text{col}}} \left( \frac{\mathbf{K}^\top \mathbf{Q}}{\sqrt{d}} + \mathbf{M} \right) \in \mathbb{R}^{d \times n}, \quad (17.3.3)$$

其中

$$\mathbf{K} := \mathbf{W}_K \mathbf{X} \in \mathbb{R}^{d \times n} \quad \text{其中某个 } \mathbf{W}_K \in \mathbb{R}^{d \times d}, \quad (17.3.4a)$$

$$\mathbf{Q} := \mathbf{W}_Q \mathbf{X} \in \mathbb{R}^{d \times n} \quad \text{其中某个 } \mathbf{W}_Q \in \mathbb{R}^{d \times d}, \quad (17.3.4b)$$

$$\mathbf{V} := \mathbf{W}_V \mathbf{X} \in \mathbb{R}^{d \times n} \quad \text{其中某个 } \mathbf{W}_V \in \mathbb{R}^{d \times d}. \quad (17.3.4c)$$

并且  $\mathbf{M} \in \{0, -\infty\}^{n \times n}$ . 矩阵  $\mathbf{M}$  称为掩码矩阵, 它是固定的, 而不是学习得到的. 若  $\mathbf{M}$  恒为零, 则对应于无掩码自注意力. 我们将着重考察

$$M_{ij} = \begin{cases} 0, & i \leq j, \\ -\infty, & i > j, \end{cases} \quad (17.3.5)$$

也就是说,  $\mathbf{M}$  的对角线下方各项为  $-\infty$ , 对角线及其上方各项为零. 在这种情形下, 式 (17.3.3) 也称为因果自注意力; 稍后会解释这一术语. 下文将回顾 softmax 函数; 它在这里是从  $\mathbb{R}^n$  到  $\mathbb{R}^n$  的映射, 并按列应用 (参见式 (17.3.1)). 矩阵  $\mathbf{W}_K$ 、 $\mathbf{W}_Q$  和  $\mathbf{W}_V$  含有可学习参数, 且这些参数与  $n$  无关.

为展开说明式 (17.3.3) 的含义, 我们先给出其余矩阵的通常解释. 这种解释完全是启发式的, 只用于为下文提供动机.

- $\mathbf{Q}$ : 矩阵  $\mathbf{W}_Q$  所表示的映射提取一个词元所寻求的信息. 因此,  $\mathbf{Q}$  的各列称为查询.
- $\mathbf{K}$ : 矩阵  $\mathbf{W}_K$  所表示的映射提取一个词元能够提供的信息. 因此,  $\mathbf{K}$  的各列称为键.
- $\mathbf{V}$ : 矩阵  $\mathbf{W}_V$  所表示的映射提取词元的含义. 因此,  $\mathbf{V}$  的各列称为值.

现在, 式 (17.3.3) 可解释为计算词元的值的线性组合, 这些值存储在  $\mathbf{V}$  的  $n$  列中. 这些线性组合的系数由 softmax 项确定. 下面更详细地讨论这些系数.

**定义 17.16:** 设  $d, n \in \mathbb{N}$ , 以  $(\mathbf{x}_1, \dots, \mathbf{x}_n)$  表示  $\mathbf{X} \in \mathbb{R}^{d \times n}$  的各列, 并对  $t \leq n$  令  $\mathbf{X}_{[t]} := (\mathbf{x}_1, \dots, \mathbf{x}_t) \in \mathbb{R}^{d \times t}$ . 对  $t = 1, \dots, n$ , 重要性分数  $\tilde{\mathcal{I}}_{[t]} \in \mathbb{R}^t$  定义为

$$\tilde{\mathcal{I}}_{[t]}(\mathbf{X}) := \frac{1}{\sqrt{d}} (\mathbf{W}_K \mathbf{X}_{[t]})^\top (\mathbf{W}_Q \mathbf{x}_t) = \frac{1}{\sqrt{d}} (\mathbf{x}_t^\top \mathbf{W}_K^\top \mathbf{W}_Q \mathbf{x}_t)_{i=1}^t \in \mathbb{R}^t.$$

重要性分数  $\tilde{\mathcal{I}}_{[t]}(\mathbf{X})$  通过计算  $\mathbf{W}_K \mathbf{x}_i$  与  $\mathbf{W}_Q \mathbf{x}_t$  在  $i = 1, \dots, t$  时的标量积, 将  $\mathbf{X}$  的第  $t$  列同其自身及所有先前的列作比较. 如果  $\mathbf{x}_i$  的键嵌入  $\mathbf{W}_K \mathbf{x}_i$  与  $\mathbf{x}_t$  的查询嵌入

$\mathbf{W}_q \mathbf{x}_t$  指向相近的方向, 那么来自该键嵌入的词 (或词元) 就与查询嵌入相匹配, 我们便认为这两个词彼此重要. 因此, 学习得到的矩阵  $\mathbf{W}_K$ 、 $\mathbf{W}_Q$  的用途是通过  $\mathbf{x}_i^\top \mathbf{W}_K^\top \mathbf{W}_Q \mathbf{x}_t$  判断词元  $\mathbf{x}_i$  是否与  $\mathbf{x}_t$  相关, 或者说位置  $i$  处的键与位置  $t$  处的查询匹配得有多好. 该值越大,  $\mathbf{x}_i$  对  $\mathbf{x}_t$  的重要性分数就越大, 后续给予它的注意力也就越多.

为了使重要性分数更便于比较和解释, 通常对其进行归一化. 因而, 下面引入归一化重要性分数; 这正是 softmax 函数的用途:

$$\text{softmax}: \mathbb{R}^t \rightarrow \mathbb{R}^t, \quad \mathbf{y} \mapsto \left( \frac{e^{y_i}}{\sum_{j=1}^t e^{y_j}} \right)_{i=1}^t. \quad (17.3.6)$$

**定义 17.17:** 设  $d, n \in \mathbb{N}$  且  $\mathbf{W}_Q, \mathbf{W}_K \in \mathbb{R}^{d \times d}$ . 对  $t = 1, \dots, n$  及  $\mathbf{X} \in \mathbb{R}^{d \times n}$ , 归一化重要性分数定义为

$$\mathcal{I}_{[t]}(\mathbf{X}) = \text{softmax}(\tilde{\mathcal{I}}_{[t]}(\mathbf{X})) \in \mathbb{R}^t.$$

|        |     |        |        |      |      |     |       |
|--------|-----|--------|--------|------|------|-----|-------|
| In     | 0.1 | 0.3    | 0.2    | 0.1  | 0.3  | 0.0 | 0.0   |
| autumn |     | 0.1    | 0.2    | 0.2  | 0.2  | 0.2 | 0.1   |
| leaves |     |        | 0.1    | 0.6  | 0.1  | 0.0 | 0.2   |
| fall   |     |        |        | 0.1  | 0.7  | 0.2 | 0.0   |
| from   |     |        |        |      | 0.1  | 0.8 | 0.1   |
| the    |     |        |        |      |      | 0.5 | 0.5   |
| trees  |     |        |        |      |      |     | 1.0   |
|        | In  | autumn | leaves | fall | from | the | trees |

图 17.5: 表示词语的输入  $\mathbf{X}$  所对应的归一化重要性分数. 各列对应查询, 各行对应键. 对查询 “fall”, 最大重要性被赋给 “leaves”, 而不是 “autumn”; 尽管在把 fall 视为名词时, “fall” 与 “autumn” 可以具有相同含义. 这是因为查询嵌入与键嵌入使重要性分数衡量词语组合得有多好, 而不只是衡量它们的相似程度.

基于归一化重要性分数, 现在可以定义 (因果) Transformer 的主要构件, 即因果自注意力机制. 对索引  $t$  处的查询, 它计算前  $t$  个值 (即  $\mathbf{V}$  的前  $t$  列) 的线性组合, 并以重要性权重  $\mathcal{I}_{[t]}$  加权; 这些权重对应于索引为  $1, \dots, t$  的键. 它的作用如此核心, 以至于原始论文 [316] 的作者将论文命名为 “Attention is all you need”.

**定义 17.18:** 设  $d, n \in \mathbb{N}$  且  $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d \times d}$ . 对  $\mathbf{X} \in \mathbb{R}^{d \times n}$ , 定义自注意力算子为

$$\Phi_{\text{at}}(\mathbf{X}; \mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V) := [(\mathbf{W}_V \mathbf{X}_{[1]})\mathcal{I}_{[1]}(\mathbf{X}), \dots, (\mathbf{W}_V \mathbf{X}_{[n]})\mathcal{I}_{[n]}(\mathbf{X})] \in \mathbb{R}^{d \times n}.$$

有时也简写为  $\Phi_{\text{at}}(\mathbf{X})$ .

由于  $\exp(-\infty) = 0$ , 式 (17.3.3) 中 softmax 项的第  $t$  列恰好对应于用零补齐的  $\mathcal{I}_{[t]}(\mathbf{X})$ . 因此, 式 (17.3.3) 是定义 17.18 中自注意力算子  $\Phi_{\text{at}}(\mathbf{X})$  的紧凑记法.

式 (17.3.5) 中的掩码矩阵  $\mathbf{M}$  保证对角线下方的归一化重要性分数为零, 因而与定义 17.17 一致. 具体而言,  $\Phi_{\text{at}}(\mathbf{X})$  的第  $t$  列包含位置  $t$  及其之前所有词语的值嵌入的一个凸组合, 其系数就是归一化重要性分数. 这意味着位置  $t$  处词语的值会根据先前词元的上下文得到更新. 对文本生成而言, 这种掩码是架构的关键组成部分: 模型应学习预测句子中的下一个词. 如果允许模型访问整个句子, 那么它只会学会把词语移动一个位置, 却无法学到生成新文本所需的结构和语义. “因果”一词由此而来, 而“自注意力”一词则源于词元彼此之间重要性分数的计算过程.

**注 17.19:** 在实际实现中, 通常会跨多个相互独立的“头”并行计算注意力. 每个头都有自身学习得到的投影, 从而产生各自的注意力分布. 随后, 将所有头的输出拼接起来并作线性变换, 形成最终结果. 这种构造称为多头注意力, 它使模型能够同时捕捉不同类型的依赖关系. 例如, 一个头可以关注句法关系, 另一个头则捕捉语义相似性.  $\diamond$

### 17.3.3 Transformer 块

如前所述, 自注意力会根据文本的上下文更新词语的值. 对于更复杂的文本, 我们希望迭代这一过程. 将多个注意力块相互复合, 恰好就得到了 Transformer.

为了提高灵活性和稳定性, 除了(多头)注意力之外, Transformer 的标准构造还包含三个关键组成部分: 残差连接、前馈层和层归一化. 前两个概念我们已经熟悉, 下面介绍归一化.

**定义 17.20:** 对  $\mathbf{x} \in \mathbb{R}^d$ , 定义层归一化为

$$\Phi_{\text{la}}: \mathbb{R}^d \rightarrow \mathbb{R}^d, \\ \mathbf{x} \mapsto \left( \frac{x_i - \mu(\mathbf{x})}{\sqrt{v(\mathbf{x})}} \right)_{i=1}^d,$$

其中  $\mu(\mathbf{x}) = \sum_{i=1}^d x_i/d$  且  $v(\mathbf{x}) = \sum_{i=1}^d (x_i - \mu(\mathbf{x}))^2/d$ .

**注 17.21:** 尽管统计学家和应用数学家可能会预期  $v$  被定义为方差的无偏估计量  $v(\mathbf{x}) = \sum_{i=1}^d (x_i - \mu(\mathbf{x}))^2/(d-1)$ , 但层归一化中实际使用的确实是定义 17.20 所给出的  $v$ , 见文献 [316].  $\diamond$

现在可以引入 Transformer 块; 同时再次提醒读者注意式 (17.3.1) 中的逐列记号.

**定义 17.22:** 设  $d, d_1, n \in \mathbb{N}$ . 设  $\Phi_{\text{at}}: \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$  是定义 17.18 所述的自注意力算子, 其参数为

$$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d \times d},$$

并设  $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^d$  是宽度为  $\max\{d, d_1\}$  的浅层(单隐藏层)前馈神经网络(参见定义 2.1), 其权重与偏置为

$$\mathbf{W}^{(0)} \in \mathbb{R}^{d_1 \times d}, \quad \mathbf{W}^{(1)} \in \mathbb{R}^{d \times d_1}, \quad \mathbf{b}^{(0)} \in \mathbb{R}^{d_1}, \quad \mathbf{b}^{(1)} \in \mathbb{R}^d, \quad (17.3.7)$$

激活函数为  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ .

对  $\mathbf{X} \in \mathbb{R}^{d \times n}$ , Transformer 块  $\Phi_{\text{tr}}: \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$  计算

$$\begin{aligned}\mathbf{Y} &:= \Phi_{\text{la}}^{\text{col}}(\mathbf{X} + \Phi_{\text{at}}(\mathbf{X})), \\ \Phi_{\text{tr}}(\mathbf{X}) &:= \Phi_{\text{la}}^{\text{col}}(\mathbf{Y} + \Phi^{\text{col}}(\mathbf{Y})).\end{aligned}$$

图 17.6 给出了 Transformer 块的示意图.

**注 17.23:** 将前馈神经网络  $\Phi$  逐列作用于  $\mathbf{Y}$ , 可以保证因果性不被破坏; 也就是说, 这一运算不会把后续词元的信息传播给先前的词元.  $\diamond$

**注 17.24:** 在文献 [316] 中, 神经网络隐藏层的宽度  $d_1$  取为  $4d$ , 激活函数  $\sigma$  取为 ReLU.  $\diamond$

**注 17.25:** 定义 17.22 给出了原始工作 [316] 中引入的架构. 然而, 后来人们发现, 将归一化块置于注意力块和神经网络之前可得到更稳定的实现 [329, 51].  $\diamond$




图 17.6: Transformer 示意图. 左侧为定义 17.22 中的 Transformer 块; 右侧展示如何用深度为  $L$  的 Transformer 生成句子下一个潜在词语的概率分布.

Transformer 就是多个 Transformer 块的复合.

**定义 17.26:** 设  $d, L, n \in \mathbb{N}$ . 设  $\Phi_{\text{tr}}^{(1)}, \dots, \Phi_{\text{tr}}^{(L)}$  为输入维数均为  $d \times n$  的 Transformer

块. Transformer 是函数  $\Phi_{\text{tr}}: \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$ , 并且对  $\mathbf{X} \in \mathbb{R}^{d \times n}$  有  $\Phi_{\text{tr}}(\mathbf{X}) = \mathbf{X}_{\text{tr}}^{(L)}$ , 其中

$$\begin{aligned}\mathbf{X}_{\text{tr}}^{(0)} &= \mathbf{X}, \\ \mathbf{X}_{\text{tr}}^{(j)} &= \Phi_{\text{tr}}^{(j)}(\mathbf{X}_{\text{tr}}^{(j-1)}) \quad \text{对 } j = 1, \dots, L.\end{aligned}$$

称  $L$  为 Transformer 的深度.

如前所述, 应用一次自注意力, 因而也就是应用一次 Transformer 块, 会以纳入文本上下文、特别是先前词元的方式更新每个位置的值. 理想情况下, 若像 Transformer 中那样多次进行这一过程, 则每个位置更新后的值都会包含其前文中使该词得以理解的全部相关信息. 下面的例子说明, 与只应用一次相比, Transformer 的多层结构如何改善值的上下文.

**例 17.27:** 考虑句子: “The leaf that fell from the tree was green.” 应用一个注意力块后, “was” 的查询可能对 “leaf” 和 “tree” 具有同样大的注意力值, 因为二者都是位于其附近的名词. 然而, 随着表示经过连续各层而不断细化, “leaf” 的键会越来越充分地编码它是句子主语这一信息, 而 “tree” 的键则编码其作用是说明作为主语的 leaf 的性质. 因此, 在更深的层中, “was” 的注意力会集中到 “leaf” 上.

这说明, 多层结构使 Transformer 能够逐步学习语法结构; 这一过程并非一步完成, 而是通过上下文信息的累积实现.  $\diamond$

当输入句子经过充分变换后, 就可以用它生成文本, 下一小节将对此加以说明.

### 17.3.4 用 Transformer 生成文本

Transformer 每次生成一个词元, 从而逐步生成句子. 这里假设词典中有  $N_T \in \mathbb{N}$  个可用词元, 并希望从中选出一个来延展已有的文本片段. 具体而言, 假设已有一个长度为  $n$  的句子, 它对应于矩阵  $\mathbf{X} \in \mathbb{R}^{d \times n}$ . 设  $\Phi_{\text{tr}}$  是深度为  $L \in \mathbb{N}$  的 Transformer, 其输入和输出维数均为  $d \times n$ .

令  $\mathbf{X}^{\text{context}} = \Phi_{\text{tr}}(\mathbf{X})$ . 输出  $\mathbf{X}^{\text{context}}$  是与  $\mathbf{X}$  所对应句子的一个表示, 它已经历了  $L$  次 Transformer 作用. 因此, 其第  $j$  列包含在先前词元的上下文下得到的版本. 特别地, 最后一列在变换过程中能够访问整个  $\mathbf{X}$ .

为了预测下一个词元, 只需考察  $\mathbf{X}^{\text{context}} = [\mathbf{x}_1^{\text{context}}, \dots, \mathbf{x}_n^{\text{context}}]$  的最后一列  $\mathbf{x}_n^{\text{context}}$ , 并对矩阵

$$\mathbf{W} \in \mathbb{R}^{N_T \times d} \tag{17.3.8}$$

计算向量

$$\mathbf{p}(\mathbf{X}) := \text{softmax}(\mathbf{W} \mathbf{x}_n^{\text{context}}) \in \mathbb{R}^{N_T}.$$

向量  $\mathbf{p}$  表示所有词元上的一个概率分布. 图 17.6 展示了这一过程. 现在选取一个被  $\mathbf{p}$  赋予较高概率的词元, 从而得到总长度为  $n + 1$  的新文本. 重复这一过程, 直至生成足够长的文本.

### 17.3.5 何时应使用 Transformer ?

当存在长程依赖时, 即输入中在序列或空间上相距很远的元素之间存在相互作用时 (例如长句中相隔很远的主语与谓语需要保持一致), Transformer 尤其有效. 这种架构足够灵活, 可以使上下文窗口随输入而改变并加以适应. 这与卷积神经网络固定且局部的窗口形成对比. 然而, 在面对小数据集时, Transformer 可能并不理想.

此外, Transformer 的一个主要缺点是, 其成本随输入词元数  $n$  二次增长. 参数矩阵

$$\mathbf{W}_K, \mathbf{W}_Q, \mathbf{W}_V \in \mathbb{R}^{d \times d}$$

以及式 (17.3.7) 中前馈层的参数和式 (17.3.8) 中最终嵌入的参数均与  $n$  无关, 但计算式 (17.3.3) 的成本为  $O(n^2)$ . 这是由下列项造成的:

$$\text{softmax}^{\text{col}}(\mathbf{X}^\top \mathbf{W}_K^\top \mathbf{W}_Q \mathbf{X} + \mathbf{M}) \in \mathbb{R}^{n \times n}.$$

还要指出, 尽管  $\mathbf{X}^\top \mathbf{W}_K^\top \mathbf{W}_Q \mathbf{X}$  的秩至多为  $d$ , 逐列应用 softmax 后所得矩阵却未必是低秩的. 文献中已经提出多种策略来应对这种二次扩展; 习题 17.31 将讨论其中一种.



## 文献与延伸阅读

关于深度学习架构的文献极其庞杂. 尤其是, 每种架构都有许多已经得到研究和应用的变体. 因此, 下面的参考文献绝非完备, 只是为读者指出若干可以找到有趣数学结果的方向.

残差网络由文献 [128] 引入, 旨在通过跳跃连接实现很深网络的训练. 文献 [186] 证明, 即使每层仅有一个神经元, 残差网络也具有万能性. 残差网络可以解释为连续时间动力系统的离散化, 这一观察推动了它与控制理论及微分方程之间的联系. 特别地, 文献 [120] 将深层残差架构解释为最优控制问题的数值格式. 此外, 文献 [59] 在神经微分方程框架中形式化了连续深度极限.

卷积神经网络源自手写字符和邮政编码识别的早期工作; 这些工作使用反向传播成功训练了卷积架构 [176, 175]. 相关数学理论主要研究逼近性质和不变性: 文献 [340] 和文献 [333] 得到了万能性结果. 此外, 文献 [237] 证明了卷积神经网络与全连接网络之间的逼近等价性. 人们还从调和分析和学习理论的视角研究了不变性与等变性, 其中较为突出的有文献 [194] 的群不变散射框架, 以及文献 [67] 的群卷积神经网络框架. 文献 [282] 研究了深层群卷积网络的 VC 理论.


Transformer 由文献 [316] 引入, 并构成了若干有影响力的大语言模型的基础 [80, 312, 64]. Transformer 架构在科学应用中也取得了突破性成果, 其中最著名的是 AlphaFold 对蛋白质结构的预测 [152]. 文献 [335, 336, 4, 119] 给出了关于 Transformer 表达能力及其逼近序列到序列映射能力的早期结果. 人们还研究了不同形式的万能性, 例如上下文学习 [98] 和下一词元预测 [270] 中的万能性. 关于 Transformer 的训练 (不) 稳定性, 可参见文献 [188]; 文献 [269, 103] 则从平均场分析的视角研究了简化设定下 Transformer 的动力学. 最后, 关于层归一化, 可参见最初的论文 [12]; 关于其一般作用及其对 Transformer 的影响, 可进一步参见文献 [331, 329].



## 习题

**17.28.** 证明：引理 17.5 证明的步骤 1 中的构造，可以用两个残差块（而非一个）和一个隐藏 ReLU（而非两个）代替。推出当  $d_1 = \cdots = d_L = 1$  时，引理 17.5 仍然成立。再说明定理 17.6 的证明也可以调整为适用于  $d_1 = \cdots = d_L = 1$ 。

提示：需要构造一个  $L = 2$ 、 $d_1 = d_2 = 1$  的 ReLU 残差网络，使其实现如下类型的函数：



**17.29.** 设  $\mathbf{X} \in \mathbb{R}^{d \times d}$ 、 $\mathbf{W} \in \mathbb{R}^{d \times d}$ ，且  $k_1, k_2 \in \{0, \dots, d_1\}$ 。证明

$$T_{k_1, k_2}(\mathbf{W} * \mathbf{X}) = (T_{k_1, k_2} \mathbf{W}) * \mathbf{X} = \mathbf{W} * (T_{k_1, k_2} \mathbf{X}).$$

**17.30.** 设  $\mathbf{s}_j$  如式 (17.3.2) 所示。证明：对所有  $j, k \in \mathbb{Z}$ ， $\mathbf{s}_j^\top \mathbf{s}_k$  是  $j - k$  的函数。

提示： $\cos(\alpha - \beta) = \cos \alpha \cos \beta + \sin \alpha \sin \beta$ 。

以下习题基于文献 [158]。

**17.31.** 假设  $\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$  是一个（特征）映射，使得对  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$ ，

$$\langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle$$

是  $\exp(\mathbf{x}^\top \mathbf{y} / \sqrt{d})$  的一个近似。

对  $\mathbf{X} \in \mathbb{R}^{d \times n}$ ，沿用式 (17.3.3)–(17.3.5) 的记号，令

$$\Phi_{\text{att}}(\mathbf{X}) = \mathbf{V} \text{softmax}^{\text{col}} \left( \frac{\mathbf{K}^\top \mathbf{Q}}{\sqrt{d}} + \mathbf{M} \right) \in \mathbb{R}^{d \times n}.$$

证明： $\Phi_{\text{att}}(\mathbf{X})$  的第  $i$  列可以由下式近似：

$$\frac{\sum_{j=1}^i \langle \phi(\mathbf{k}_j), \phi(\mathbf{q}_i) \rangle \mathbf{v}_j}{\sum_{j=1}^i \langle \phi(\mathbf{k}_j), \phi(\mathbf{q}_i) \rangle}. \quad (17.3.9)$$

这里， $\mathbf{k}_i$ 、 $\mathbf{q}_i$ 、 $\mathbf{v}_i$  分别表示式 (17.3.4) 中  $\mathbf{K}$ 、 $\mathbf{Q}$ 、 $\mathbf{V}$  的第  $i$  列。基于式 (17.3.9)，给出一个关于上下文长度  $n$  具有  $O(n)$  复杂度的算法，用以近似计算  $\Phi_{\text{att}}: \mathbb{R}^{d \times n} \rightarrow \mathbb{R}^{d \times n}$ 。 $\phi$  的一个适当选择是什么？

# 概率论

本附录介绍正文所需的一些概率论基本概念与结果. 本附录旨在帮助已经熟悉这些概念的读者复习; 关于更多细节与证明, 例如可参阅标准教材 [162].

## A.1 Sigma-代数、拓扑与测度

设  $\Omega$  是一个集合, 并以  $2^\Omega$  表示  $\Omega$  的幂集.

**定义 A.1:** 若子集  $\mathfrak{A} \subseteq 2^\Omega$  满足

1.  $\Omega \in \mathfrak{A}$ ;
2. 只要  $A \in \mathfrak{A}$ , 就有  $A^c \in \mathfrak{A}$ ;
3. 只要对所有  $i \in \mathbb{N}$  都有  $A_i \in \mathfrak{A}$ , 就有  $\bigcup_{i \in \mathbb{N}} A_i \in \mathfrak{A}$ ,

则称其为  $\Omega$  上的 **sigma-代数**<sup>1</sup>.

对  $\Omega$  上的 sigma-代数  $\mathfrak{A}$ , 二元组  $(\Omega, \mathfrak{A})$  也称为**可测空间**. 对于可测空间, 若子集  $A \subseteq \Omega$  满足  $A \in \mathfrak{A}$ , 则称  $A$  **可测**. 可测集也称为**事件**.

$\Omega$  的另一类重要子集系统是拓扑.

**定义 A.2:** 若子集  $\mathfrak{T} \subseteq 2^\Omega$  满足

1.  $\emptyset, \Omega \in \mathfrak{T}$ ;
2. 只要  $n \in \mathbb{N}$  且  $O_1, \dots, O_n \in \mathfrak{T}$ , 就有  $\bigcap_{j=1}^n O_j \in \mathfrak{T}$ ;
3. 对任意指标集  $I$ , 只要对所有  $i \in I$  都有  $O_i \in \mathfrak{T}$ , 就有  $\bigcup_{i \in I} O_i \in \mathfrak{T}$ ,

则称其为  $\Omega$  上的**拓扑**. 若  $\mathfrak{T}$  是  $\Omega$  上的拓扑, 则称  $(\Omega, \mathfrak{T})$  为**拓扑空间**; 当且仅当  $O \in \mathfrak{T}$  时, 称集合  $O \subseteq \Omega$  为**开集**.

**注 A.3:** 这两个概念的区别在于: 拓扑允许对任意多个集合 (可能不可数) 取并, 但只允许取有限交; sigma-代数则允许取可数并与可数交.  $\diamond$

**例 A.4:** 设  $d \in \mathbb{N}$ , 并以  $B_\varepsilon(\mathbf{x}) = \{\mathbf{y} \in \mathbb{R}^d \mid \|\mathbf{y} - \mathbf{x}\| < \varepsilon\}$  表示与  $\mathbf{x}$  的 Euclidean 距离小于  $\varepsilon$  的点集. 对每个  $A \subseteq \mathbb{R}^d$ , 包含所有  $A \cap B_\varepsilon(\mathbf{x})$  ( $\varepsilon > 0, \mathbf{x} \in \mathbb{R}^d$ ) 的  $A$  上最小拓扑, 称为  $A$  上的 **Euclidean 拓扑**.  $\diamond$

<sup>1</sup>这里采用这一写法, 而不采用更常见的 “ $\sigma$ -代数”, 以免与激活函数  $\sigma$  混淆.

若  $(\Omega, \mathfrak{T})$  是拓扑空间, 则 **Borel sigma-代数** 是指  $\Omega$  上包含所有开集 (即  $\mathfrak{T}$  的所有元素) 的最小 sigma-代数. 本书始终约定  $\mathbb{R}^d$  的子集配备 Euclidean 拓扑和 Borel sigma-代数.  $\mathbb{R}^d$  上的 Borel sigma-代数记作  $\mathfrak{B}_d$ .

现在可以引入测度.

**定义 A.5:** 设  $(\Omega, \mathfrak{A})$  是可测空间. 若映射  $\mu: \mathfrak{A} \rightarrow [0, \infty]$  满足

1.  $\mu(\emptyset) = 0$ ;
2. 对每个序列  $(A_i)_{i \in \mathbb{N}} \subseteq \mathfrak{A}$ , 只要在  $i \neq j$  时有  $A_i \cap A_j = \emptyset$ , 就有

$$\mu\left(\bigcup_{i \in \mathbb{N}} A_i\right) = \sum_{i \in \mathbb{N}} \mu(A_i).$$

则称  $\mu$  为 **测度**. 若  $\mu(\Omega) < \infty$ , 则称该测度为 **有限测度**; 若存在序列  $(A_i)_{i \in \mathbb{N}} \subseteq \mathfrak{A}$ , 使得  $\Omega = \bigcup_{i \in \mathbb{N}} A_i$  且对所有  $i \in \mathbb{N}$  都有  $\mu(A_i) < 1$ , 则称其为 **sigma-有限测度**. 当  $\mu(\Omega) = 1$  时, 称该测度为 **概率测度**.

**例 A.6:** 可以证明,  $(\mathbb{R}^d, \mathfrak{B}_d)$  上存在唯一测度  $\lambda$ , 使得对所有形如  $\times_{j=1}^d [a_i, b_i)$  且  $-\infty < a_i \leq b_i < \infty$  的集合, 都有

$$\lambda\left(\times_{i=1}^d [a_i, b_i)\right) = \prod_{i=1}^d (b_i - a_i).$$

这一测度称为 **Lebesgue 测度**. ◇

若  $\mu$  是可测空间  $(\Omega, \mathfrak{A})$  上的测度, 则称三元组  $(\Omega, \mathfrak{A}, \mu)$  为 **测度空间**. 当  $\mu$  是概率测度时, 称其为 **概率空间**.

设  $(\Omega, \mathfrak{A}, \mu)$  是测度空间. 若子集  $N \subseteq \Omega$  可测且  $\mu(N) = 0$ , 则称  $N$  为 **零测集**. 此外, 若一个等式或不等式在某个零测集的补集上成立, 则称其  **$\mu$ -几乎处处成立** 或  **$\mu$ -几乎必然成立**. 当由语境可以明确  $\mu$  时, 就简称 “几乎处处” 或 “几乎必然”. 通常这里指 Lebesgue 测度.

## A.2 随机变量

### A.2.1 函数的可测性

为了定义随机变量, 首先需要回顾函数的可测性.

**定义 A.7:** 设  $(\Omega_1, \mathfrak{A}_1)$  和  $(\Omega_2, \mathfrak{A}_2)$  是两个可测空间. 若函数  $f: \Omega_1 \rightarrow \Omega_2$  满足

$$f^{-1}(A_2) := \{\omega \in \Omega_1 \mid f(\omega) \in A_2\} \in \mathfrak{A}_1 \quad \text{对所有 } A_2 \in \mathfrak{A}_2,$$

则称  $f$  **可测**. 若映射  $X: \Omega_1 \rightarrow \Omega_2$  可测, 则称其为 **取值于  $\Omega_2$  的随机变量**.

**注 A.8:** 这里再次指出它与拓扑空间之间的平行关系: 两个拓扑空间  $(\Omega_1, \mathfrak{T}_1)$  和  $(\Omega_2, \mathfrak{T}_2)$  之间的函数  $f: \Omega_1 \rightarrow \Omega_2$ , 若对所有  $O_2 \in \mathfrak{T}_2$  都有  $f^{-1}(O_2) \in \mathfrak{T}_1$ , 则称其 **连续**. ◇

设  $\Omega_1$  是一个集合, 且  $(\Omega_2, \mathfrak{A}_2)$  是可测空间. 对  $X: \Omega_1 \rightarrow \Omega_2$ , 可以寻找  $\Omega_1$  上使  $X$  作为从  $(\Omega_1, \mathfrak{A}_X)$  到  $(\Omega_2, \mathfrak{A}_2)$  的映射可测的最小 sigma-代数  $\mathfrak{A}_X$ . 显然, 对  $\Omega_1$  上的每个 sigma-代数  $\mathfrak{A}_1$ ,  $X$  作为从  $(\Omega_1, \mathfrak{A}_1)$  到  $(\Omega_2, \mathfrak{A}_2)$  的映射可测, 当且仅当每个  $A \in \mathfrak{A}_X$  都属于  $\mathfrak{A}_1$ ; 换言之,  $\mathfrak{A}_X$  是  $\mathfrak{A}_1$  的子 sigma-代数. 容易验证,  $\mathfrak{A}_X$  可由以下定义给出.

**定义 A.9:** 设  $X: \Omega_1 \rightarrow \Omega_2$  是随机变量. 则

$$\mathfrak{A}_X := \{X^{-1}(A_2) \mid A_2 \in \mathfrak{A}_2\} \subseteq 2^{\Omega_1}$$

是  $\Omega_1$  上由  $X$  诱导的 sigma-代数.

### A.2.2 分布与期望

现在设  $(\Omega_1, \mathfrak{A}_1, \mathbb{P})$  是概率空间, 且  $(\Omega_2, \mathfrak{A}_2)$  是可测空间. 那么  $X$  自然地通过

$$\mathbb{P}_X[A_2] := \mathbb{P}[X^{-1}(A_2)] \quad \text{对所有 } A_2 \in \mathfrak{A}_2$$

在  $(\Omega_2, \mathfrak{A}_2)$  上诱导出一个测度. 注意, 由  $X$  的可测性有  $X^{-1}(A_2) \in \mathfrak{A}_1$ , 故  $\mathbb{P}_X$  有良好定义.

**定义 A.10:** 测度  $\mathbb{P}_X$  称为  $X$  的**分布**. 若  $(\Omega_2, \mathfrak{A}_2) = (\mathbb{R}^d, \mathfrak{B}_d)$ , 并且存在函数  $f_X: \mathbb{R}^d \rightarrow \mathbb{R}$ , 使得

$$\mathbb{P}[A] = \int_A f_X(\mathbf{x}) d\mathbf{x} \quad \text{对所有 } A \in \mathfrak{B}_d,$$

则称  $f_X$  为  $X$  的 **(Lebesgue) 密度**.

**注 A.11:** 使用“分布”一词时, 往往不明确指定底层概率空间和随机变量. 此时, “分布”与“概率测度”可以互换使用. 例如,  $\mu$  是  $\Omega_2$  上的一个分布, 表示  $\mu$  是可测空间  $(\Omega_2, \mathfrak{A}_2)$  上的概率测度. 在这种情况下, 总存在概率空间  $(\Omega_1, \mathfrak{A}_1, \mathbb{P})$  和随机变量  $X: \Omega_1 \rightarrow \Omega_2$ , 使得  $\mathbb{P}_X = \mu$ ; 具体可取  $(\Omega_1, \mathfrak{A}_1, \mathbb{P}) = (\Omega_2, \mathfrak{A}_2, \mu)$  以及  $X(\omega) = \omega$ .  $\diamond$

**例 A.12:** 一些重要的分布包括:

- **Bernoulli 分布:** 若存在  $p \in [0, 1]$ , 使得  $\mathbb{P}[X = 1] = p$  且  $\mathbb{P}[X = 0] = 1 - p$ , 则称随机变量  $X: \Omega \rightarrow \{0, 1\}$  服从 Bernoulli 分布.
- **均匀分布:** 若随机变量  $X: \Omega \rightarrow \mathbb{R}^d$  在可测集  $A \in \mathfrak{B}_d$  上的密度为

$$f_X(\mathbf{x}) = \frac{1}{|A|} \mathbf{1}_A(\mathbf{x}),$$

其中  $|A| < \infty$  是  $A$  的 Lebesgue 测度, 则称  $X$  在  $A$  上均匀分布.

- **Gaussian 分布:** 若随机变量  $X: \Omega \rightarrow \mathbb{R}^d$  的均值为  $\mathbf{m} \in \mathbb{R}^d$ 、可逆协方差矩阵为  $\mathbf{C} \in \mathbb{R}^{d \times d}$ , 且其密度为

$$f_X(\mathbf{x}) = \frac{1}{(2\pi \det(\mathbf{C}))^{d/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{m})^\top \mathbf{C}^{-1}(\mathbf{x} - \mathbf{m})\right),$$

则称  $X$  服从 Gaussian 分布. 这一分布记作  $N(\mathbf{m}, \mathbf{C})$ .  $\diamond$

设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间, 且  $X: \Omega \rightarrow \mathbb{R}^d$  是取值于  $\mathbb{R}^d$  的随机变量. 称 Lebesgue 积分

$$\mathbb{E}[X] := \int_{\Omega} X(\omega) d\mathbb{P}(\omega) = \int_{\mathbb{R}^d} \mathbf{x} d\mathbb{P}_X(\mathbf{x}) \quad (\text{A.2.1})$$

为  $X$  的**期望**. 此外, 对  $k \in \mathbb{N}$ , 若  $\mathbb{E}[\|X\|^k] < \infty$ , 则称  $X$  具有**有限  $k$  阶矩**. 类似地, 对  $\mathbb{R}^d$  上的概率测度  $\mu$  和  $k \in \mathbb{N}$ , 若

$$\int_{\mathbb{R}^d} \|\mathbf{x}\|^k d\mu(\mathbf{x}) < \infty,$$

则称  $\mu$  具有有限  $k$  阶矩. 进一步, 矩阵

$$\int_{\Omega} (X(\omega) - \mathbb{E}[X])(X(\omega) - \mathbb{E}[X])^{\top} d\mathbb{P}(\omega) \in \mathbb{R}^{d \times d}$$

称为  $X: \Omega \rightarrow \mathbb{R}^d$  的**协方差**. 当  $d = 1$  时, 它称为  $X$  的**方差**, 记作  $\mathbb{V}[X]$ .

最后回顾随机变量的几种不同收敛方式.

**定义 A.13:** 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间,  $X_j: \Omega \rightarrow \mathbb{R}^d$  ( $j \in \mathbb{N}$ ) 是随机变量序列, 且  $X: \Omega \rightarrow \mathbb{R}^d$  也是随机变量. 称该序列

1. **几乎必然收敛于  $X$** , 若

$$\mathbb{P} \left[ \left\{ \omega \in \Omega \mid \lim_{j \rightarrow \infty} X_j(\omega) = X(\omega) \right\} \right] = 1,$$

2. **依概率收敛于  $X$** , 若

$$\text{对所有 } \varepsilon > 0: \quad \lim_{j \rightarrow \infty} \mathbb{P}[\{\omega \in \Omega \mid |X_j(\omega) - X(\omega)| > \varepsilon\}] = 0,$$

3. **依分布收敛于  $X$** , 若对所有有界连续函数  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  都有

$$\lim_{j \rightarrow \infty} \mathbb{E}[f \circ X_j] = \mathbb{E}[f \circ X].$$

定义 A.13 中的概念按强弱递减排列, 即几乎必然收敛蕴含依概率收敛, 而依概率收敛蕴含依分布收敛; 例如见文献 [162, 第 13 章]. 由于  $\mathbb{E}[f \circ X] = \int_{\mathbb{R}^d} f(x) d\mathbb{P}_X(x)$ , 依分布收敛的概念仅依赖于  $X$  的分布  $\mathbb{P}_X$ . 因此, 也可以说一个随机变量序列依分布收敛于测度  $\mu$ .

### A.3 条件分布、边缘分布与独立性

本节集中讨论取值于  $\mathbb{R}^d$  的随机变量, 不过下述概念也可以推广到更一般的空间.

### A.3.1 联合分布与边缘分布

再次设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间, 并设  $X: \Omega \rightarrow \mathbb{R}^{d_X}$ 、 $Y: \Omega \rightarrow \mathbb{R}^{d_Y}$  是两个随机变量. 那么

$$Z := (X, Y): \Omega \rightarrow \mathbb{R}^{d_X+d_Y}$$

也是随机变量. 它的分布  $\mathbb{P}_Z$  是可测空间  $(\mathbb{R}^{d_X+d_Y}, \mathfrak{B}_{d_X+d_Y})$  上的测度, 并称  $\mathbb{P}_Z$  为  $X$  与  $Y$  的**联合分布**. 另一方面,  $\mathbb{P}_X$ 、 $\mathbb{P}_Y$  称为  $X$ 、 $Y$  的**边缘分布**. 注意

$$\mathbb{P}_X[A] = \mathbb{P}_Z[A \times \mathbb{R}^{d_Y}] \quad \text{对所有 } A \in \mathfrak{B}_{d_X},$$

对  $\mathbb{P}_Y$  也有类似结论. 因而, 可以由联合分布  $\mathbb{P}_Z$  构造边缘分布  $\mathbb{P}_X$ 、 $\mathbb{P}_Y$ . 反之, 仅知道边缘分布不足以构造联合分布.

### A.3.2 独立性

独立性的概念用于形式化如下情形: 知道一个随机变量的信息不会提供关于另一个随机变量的信息. 我们先给出形式定义, 然后以掷骰子为简单例子进行讨论.

**定义 A.14:** 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间. 若两个事件  $A, B \in \mathfrak{A}$  满足

$$\mathbb{P}[A \cap B] = \mathbb{P}[A]\mathbb{P}[B],$$

则称它们**独立**. 若两个随机变量  $X: \Omega \rightarrow \mathbb{R}^{d_X}$  和  $Y: \Omega \rightarrow \mathbb{R}^{d_Y}$  满足

$$\text{对所有 } A \in \mathfrak{A}_X, B \in \mathfrak{A}_Y, \quad A, B \text{ 独立},$$

则称它们**独立**.

因此, 两个随机变量独立, 当且仅当它们所诱导的 sigma-代数中的所有事件都独立. 这等价于联合分布  $\mathbb{P}_{(X,Y)}$  等于乘积测度  $\mathbb{P}_X \otimes \mathbb{P}_Y$ ; 后者刻画为  $\mathbb{R}^{d_X+d_Y}$  上满足  $\mu(A \times B) = \mathbb{P}_X[A]\mathbb{P}_Y[B]$  (对所有  $A \in \mathfrak{B}_{d_X}$ 、 $B \in \mathfrak{B}_{d_Y}$ ) 的唯一测度  $\mu$ .

**例 A.15:** 设  $\Omega = \{1, \dots, 6\}$  表示掷一枚公平骰子的结果,  $\mathfrak{A} = 2^\Omega$  为 sigma-代数, 并且对所有  $\omega \in \Omega$  都有  $\mathbb{P}[\omega] = 1/6$ . 考虑三个随机变量

$$\begin{aligned} X_1(\omega) &= \begin{cases} 0, & \text{若 } \omega \text{ 为奇数,} \\ 1, & \text{若 } \omega \text{ 为偶数,} \end{cases} & X_2(\omega) &= \begin{cases} 0, & \text{若 } \omega \leq 3, \\ 1, & \text{若 } \omega \geq 4, \end{cases} \\ X_3(\omega) &= \begin{cases} 0, & \text{若 } \omega \in \{1, 2\}, \\ 1, & \text{若 } \omega \in \{3, 4\}, \\ 2, & \text{若 } \omega \in \{5, 6\}. \end{cases} \end{aligned}$$

这些随机变量可以解释如下:

- $X_1$  表示掷出的数是奇数还是偶数.

- $X_2$  表示掷出的数至多为 3 还是至少为 4.
- $X_3$  将掷出的数归入  $\{1, 2\}$ 、 $\{3, 4\}$  或  $\{5, 6\}$  三组之一.

诱导出的 sigma-代数为

$$\begin{aligned}\mathfrak{A}_{X_1} &= \{\emptyset, \Omega, \{1, 3, 5\}, \{2, 4, 6\}\}, \\ \mathfrak{A}_{X_2} &= \{\emptyset, \Omega, \{1, 2, 3\}, \{4, 5, 6\}\}, \\ \mathfrak{A}_{X_3} &= \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}, \{5, 6\}, \{1, 2, 3, 4\}, \{1, 2, 5, 6\}, \{3, 4, 5, 6\}\}.\end{aligned}$$

我们留给读者形式地验证： $X_1$  与  $X_2$  不独立，而  $X_1$  与  $X_3$  独立. 这反映了如下事实：例如，知道结果为奇数，会使该数属于  $\{1, 2, 3\}$  的可能性高于属于  $\{4, 5, 6\}$  的可能性. 然而，这一信息不会提供关于  $\{1, 2\}$ 、 $\{3, 4\}$  和  $\{5, 6\}$  这三个类别的信息.  $\diamond$

若  $X: \Omega \rightarrow \mathbb{R}$ 、 $Y: \Omega \rightarrow \mathbb{R}$  是两个独立随机变量，则由  $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$  有

$$\begin{aligned}\mathbb{E}[XY] &= \int_{\Omega} X(\omega)Y(\omega) d\mathbb{P}(\omega) \\ &= \int_{\mathbb{R}^2} xy d\mathbb{P}_{(X,Y)}(x, y) \\ &= \int_{\mathbb{R}} x d\mathbb{P}_X(x) \int_{\mathbb{R}} y d\mathbb{P}_Y(y) \\ &= \mathbb{E}[X]\mathbb{E}[Y].\end{aligned}$$

利用这一观察，容易看出：对一列二阶矩有界的独立实值随机变量  $(X_i)_{i=1}^n$ ，有 **Bienaymé 恒等式**

$$\mathbb{V}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{V}[X_i]. \quad (\text{A.3.1})$$

### A.3.3 条件分布

设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间，并设  $A, B \in \mathfrak{A}$  是两个事件. 当  $\mathbb{P}[B] > 0$  时，定义

$$\mathbb{P}[A|B] := \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}, \quad (\text{A.3.2})$$

并称  $\mathbb{P}[A|B]$  为**给定  $B$  时  $A$  的条件概率**.

**例 A.16:** 考虑例 A.15 中的设置. 令  $A = \{\omega \in \Omega \mid X_1(\omega) = 0\}$  为掷骰子的结果是奇数这一事件，并令  $B = \{\omega \in \Omega \mid X_2(\omega) = 0\}$  为掷出的数至多为 3 这一事件. 那么  $\mathbb{P}[B] = 1/2$  且  $\mathbb{P}[A \cap B] = 1/3$ . 因此

$$\mathbb{P}[A|B] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]} = \frac{1/3}{1/2} = \frac{2}{3}.$$

这反映出：已知掷出的数至多为 3 时，该数为奇数（即属于  $\{1, 3\}$ ）的概率大于该数为偶数（即等于 2）的概率.  $\diamond$



式 (A.3.2) 中的条件概率仅在  $\mathbb{P}[B] > 0$  时有良好定义. 实际中, 我们常会遇到希望对概率为零的事件取条件的情形.

**例 A.17:** 考虑如下过程: 先按照  $[0, 1]$  上的均匀分布抽取一个随机数  $p \in [0, 1]$ . 随后按照参数为  $p$  的 Bernoulli 分布抽取随机数  $X \in \{0, 1\}$ , 即  $\mathbb{P}[X = 1] = p$  且  $\mathbb{P}[X = 0] = 1 - p$ . 那么  $(p, X)$  是取值于  $[0, 1] \times \{0, 1\}$  的联合随机变量. 此时  $\mathbb{P}[X = 1|p = 0.5]$  是多少? 直观上它应为  $1/2$ , 但注意  $\mathbb{P}[p = 0.5] = 0$ , 所以式 (A.3.2) 在这里没有意义.  $\diamond$

**定义 A.18** (正则条件分布): 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间, 并设  $X: \Omega \rightarrow \mathbb{R}^{d_X}$  和  $Y: \Omega \rightarrow \mathbb{R}^{d_Y}$  是两个随机变量. 设  $\tau_{X|Y}: \mathfrak{B}_{d_X} \times \mathbb{R}^{d_Y} \rightarrow [0, 1]$  满足

1. 对每个固定的  $A \in \mathfrak{B}_{d_X}$ , 映射  $y \mapsto \tau_{X|Y}(A, y): \mathbb{R}^{d_Y} \rightarrow [0, 1]$  可测;
2. 对每个  $y \in Y(\Omega)$ , 映射  $A \mapsto \tau_{X|Y}(A, y)$  是  $(\mathbb{R}^{d_X}, \mathfrak{B}_{d_X})$  上的概率测度;
3. 对所有  $A \in \mathfrak{B}_{d_X}$  和所有  $B \in \mathfrak{B}_{d_Y}$ , 都有

$$\mathbb{P}[X \in A, Y \in B] = \int_B \tau_{X|Y}(A, y) \mathbb{P}_Y(y).$$

则称  $\tau$  为给定  $Y$  时  $X$  的正则条件分布 (版本). 此时记

$$\mathbb{P}[X \in A|Y = y] := \tau_{X|Y}(A, y),$$

并称这一测度为  $X|Y = y$  的条件分布.

定义 A.18 给出了一种数学上严格的方法, 可以为在概率可能为零的事件下取条件的随机变量赋予分布, 如例 A.17 所示. 这些条件分布的存在性与唯一性在以下意义下成立; 例如可参见文献 [162, 第 8 章], 或参见文献 [272, 第 3 章] 中这里所给的具体陈述.

**定理 A.19:** 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间, 并设  $X: \Omega \rightarrow \mathbb{R}^{d_X}$ 、 $Y: \Omega \rightarrow \mathbb{R}^{d_Y}$  是两个随机变量. 那么存在条件分布的一个正则版本  $\tau_1$ .

设  $\tau_2$  是条件分布的另一个正则版本. 那么存在一个  $\mathbb{P}_Y$ -零测集  $N \subseteq \mathbb{R}^{d_Y}$ , 使得对所有  $y \in N^c \cap Y(\Omega)$ , 两个概率测度  $\tau_1(\cdot, y)$  与  $\tau_2(\cdot, y)$  相同.

特别地, 条件分布仅在  $\mathbb{P}_Y$ -几乎处处的意义下有良好定义.

**定义 A.20:** 设  $(\Omega, \mathfrak{A}, \mathbb{P})$  是概率空间, 并设  $X: \Omega \rightarrow \mathbb{R}^{d_X}$ 、 $Y: \Omega \rightarrow \mathbb{R}^{d_Y}$ 、 $Z: \Omega \rightarrow \mathbb{R}^{d_Z}$  是三个随机变量. 若对  $\mathbb{P}_Y$ -几乎每个  $y \in Y(\Omega)$ , 两个分布  $X|Y = y$  与  $Z|Y = y$  都独立, 则称  $X$  与  $Z$  在给定  $Y$  时条件独立.

## A.4 集中不等式

设  $X_i: \Omega \rightarrow \mathbb{R}$  ( $i \in \mathbb{N}$ ) 是一列具有有限一阶矩的随机变量. 前  $n$  项的中心化平均

$$S_n := \frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \quad (\text{A.4.1})$$

也是随机变量，并且由期望的线性性有  $\mathbb{E}[S_n] = 0$ . 若

$$\mathbb{P}\left[\limsup_{n \rightarrow \infty} |S_n| = 0\right] = 1,$$

则称该序列满足**强大数定律**. 例如，若存在  $C < \infty$ ，使得对所有  $i \in \mathbb{N}$  都有  $\mathbb{V}[X_i] \leq C$ ，便属于这种情形. 集中不等式给出这一收敛速率的界.

先从 Markov 不等式开始.

**引理 A.21** (Markov 不等式): 设  $X: \Omega \rightarrow \mathbb{R}$  是随机变量，并设  $\varphi: [0, \infty) \rightarrow [0, \infty)$  单调递增. 那么对所有  $\varepsilon > 0$ ,

$$\mathbb{P}[|X| \geq \varepsilon] \leq \frac{\mathbb{E}[\varphi(|X|)]}{\varphi(\varepsilon)}.$$

**证明:** 有

$$\begin{aligned} \mathbb{P}[|X| \geq \varepsilon] &= \int_{X^{-1}([\varepsilon, \infty))} 1 \, d\mathbb{P}(\omega) \\ &\leq \int_{\Omega} \frac{\varphi(|X(\omega)|)}{\varphi(\varepsilon)} \, d\mathbb{P}(\omega) \\ &= \frac{\mathbb{E}[\varphi(|X|)]}{\varphi(\varepsilon)}, \end{aligned}$$

这便得到所述结论. □

对随机变量  $X - \mathbb{E}[X]$  应用取  $\varphi(x) := x^2$  的 Markov 不等式，直接得到 Chebyshev 不等式.

**引理 A.22** (Chebyshev 不等式): 设  $X: \Omega \rightarrow \mathbb{R}$  是具有有限方差的随机变量. 那么对所有  $\varepsilon > 0$ ,

$$\mathbb{P}[|X - \mathbb{E}[X]| \geq \varepsilon] \leq \frac{\mathbb{V}[X]}{\varepsilon^2}.$$

由 Chebyshev 不等式可得下一个结果；它是适用于具有有限方差的随机变量的一条相当一般的集中不等式.

**定理 A.23:** 设  $X_1, \dots, X_n$  是  $n \in \mathbb{N}$  个独立实值随机变量，并且存在某个  $\varsigma > 0$ ，使得对所有  $i = 1, \dots, n$  都有  $\mathbb{E}[|X_i - \mu|^2] \leq \varsigma^2$ . 记

$$\mu := \mathbb{E}\left[\frac{1}{n} \sum_{j=1}^n X_j\right]. \tag{A.4.2}$$

那么对所有  $\varepsilon > 0$ ,

$$\mathbb{P}\left[\left|\frac{1}{n} \sum_{j=1}^n X_j - \mu\right| \geq \varepsilon\right] \leq \frac{\varsigma^2}{\varepsilon^2 n}.$$

**证明：** 令  $S_n = \sum_{j=1}^n (X_j - \mathbb{E}[X_j])/n = (\sum_{j=1}^n X_j)/n - \mu$ . 由 Bienaymé 恒等式 (A.3.1), 有

$$\mathbb{V}[S_n] = \frac{1}{n^2} \sum_{j=1}^n \mathbb{E}[(X_j - \mathbb{E}[X_j])^2] \leq \frac{\zeta^2}{n}.$$

由于  $\mathbb{E}[S_n] = 0$ , 将 Chebyshev 不等式应用于  $S_n$  即得结论.  $\square$

若还有关于这些随机变量的额外信息, 就可以导出更尖锐的界. 对一致有界的随机变量 (而非仅仅方差有界), 下面回顾的 Hoeffding 不等式给出围绕均值的指数集中速率.

**定理 A.24** (Hoeffding 不等式): 设  $a, b \in \mathbb{R}$ . 设  $X_1, \dots, X_n$  是  $n \in \mathbb{N}$  个独立实值随机变量, 并且对所有  $i = 1, \dots, n$  都几乎必然有  $a \leq X_i \leq b$ ; 再设  $\mu$  如式 (A.4.2) 所定义. 那么对每个  $\varepsilon > 0$ ,

$$\mathbb{P} \left[ \left| \frac{1}{n} \sum_{j=1}^n X_j - \mu \right| > \varepsilon \right] \leq 2e^{-\frac{2n\varepsilon^2}{(b-a)^2}}.$$

例如可在文献 [285, 第 B.4 节] 中找到证明, 这一版本也取自该文献.

最后回顾多元形式的中心极限定理. 若随机变量序列  $(X_j)_{j \in \mathbb{N}}$  中的随机变量 (两两) 独立且同分布, 则称其为**独立同分布随机变量序列**. 证明见文献 [162, 定理 15.58].

**定理 A.25** (多元中心极限定理): 设  $(\mathbf{X}_n)_{n \in \mathbb{N}}$  是一列取值于  $\mathbb{R}^d$  的独立同分布随机变量, 并且对所有  $i, j = 1, \dots, d$  都有  $\mathbb{E}[\mathbf{X}_n] = \mathbf{0} \in \mathbb{R}^d$  以及  $\mathbb{E}[X_{n,i}X_{n,j}] = C_{ij}$ . 令

$$\mathbf{Y}_n := \frac{\mathbf{X}_1 + \dots + \mathbf{X}_n}{\sqrt{n}} \in \mathbb{R}^d.$$

那么当  $n \rightarrow \infty$  时,  $\mathbf{Y}_n$  依分布收敛于  $N(\mathbf{0}, \mathbf{C})$ .

## 线性代数与泛函分析

本附录介绍正文所需的一些线性代数与泛函分析基本概念和结果. 本附录旨在帮助已经熟悉这些概念的读者复习; 关于更多细节与证明, 例如可参阅标准教材 [37, 264, 265, 68, 115].

### B.1 奇异值分解与伪逆

设  $\mathbf{A} \in \mathbb{R}^{m \times n}$ ,  $m, n \in \mathbb{N}$ .  $\mathbf{A}^\top \mathbf{A}$  (或等价地  $\mathbf{A} \mathbf{A}^\top$ ) 的正特征值的平方根称为  $\mathbf{A}$  的**奇异值**. 下文将它们记作  $s_1 \geq s_2 \cdots \geq s_r > 0$ , 其中  $r := \text{rank}(\mathbf{A})$ , 故  $r \leq \min\{m, n\}$ . 每个矩阵都具有下一定理所述的**奇异值分解 (SVD)**, 例如见文献 [37, 定理 1.2.1]. 回顾: 若矩阵  $\mathbf{V} \in \mathbb{R}^{n \times n}$  满足  $\mathbf{V}^\top \mathbf{V}$  为单位矩阵, 则称其为**正交矩阵**.

**定理 B.1** (奇异值分解): 设  $\mathbf{A} \in \mathbb{R}^{m \times n}$ . 那么存在正交矩阵  $\mathbf{U} \in \mathbb{R}^{m \times m}$ 、 $\mathbf{V} \in \mathbb{R}^{n \times n}$ , 使得令

$$\Sigma := \begin{pmatrix} s_1 & & & 0 \\ & \ddots & & \\ & & s_r & \\ 0 & & & 0 \end{pmatrix} \in \mathbb{R}^{m \times n}$$

时, 有  $\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^\top$ , 其中  $\mathbf{0}$  表示适当大小的零块.

给定  $\mathbf{y} \in \mathbb{R}^m$ , 考虑线性方程组

$$\mathbf{A} \mathbf{w} = \mathbf{y}. \quad (\text{B.1.1})$$

若  $\mathbf{A}$  不是可逆方阵, 则一般而言, 式 (B.1.1) 未必存在唯一解  $\mathbf{w} \in \mathbb{R}^n$ . 然而, 存在唯一的**最小范数解**

$$\mathbf{w}_* = \operatorname{argmin}_{\mathbf{w} \in M} \|\mathbf{w}\|, \quad M = \{\mathbf{w} \in \mathbb{R}^m \mid \|\mathbf{A} \mathbf{w} - \mathbf{y}\| \leq \|\mathbf{A} \mathbf{v} - \mathbf{y}\| \ \forall \mathbf{v} \in \mathbb{R}^n\}. \quad (\text{B.1.2})$$

最小范数解可以借助  $\mathbf{A}$  的 **Moore–Penrose 伪逆**  $\mathbf{A}^\dagger \in \mathbb{R}^{n \times m}$  表示; 给定一个 (任意的) SVD  $\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^\top$ , 定义

$$\mathbf{A}^\dagger := \mathbf{V} \Sigma^\dagger \mathbf{U}^\top \quad \text{其中} \quad \Sigma^\dagger := \begin{pmatrix} s_1^{-1} & & & 0 \\ & \ddots & & \\ & & s_r^{-1} & \\ 0 & & & 0 \end{pmatrix} \in \mathbb{R}^{n \times m}. \quad (\text{B.1.3})$$

下一个定理精确表述了这一点, 例如见文献 [37, 定理 1.2.10].

**定理 B.2:** 设  $A \in \mathbb{R}^{m \times n}$ . 那么式 (B.1.2) 中存在唯一的最小范数解  $w_* \in \mathbb{R}^n$ , 并且  $w_* = A^\dagger y$ .

**证明:** 以  $\Sigma_r \in \mathbb{R}^{r \times r}$  表示  $\Sigma$  的左上象限. 由于  $U \in \mathbb{R}^{m \times m}$  正交,

$$\|Aw - y\| = \left\| \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix} V^\top w - U^\top y \right\|.$$

因此, 可以把式 (B.1.2) 中的  $M$  写成

$$\begin{aligned} M &= \left\{ w \in \mathbb{R}^n \mid \left( \begin{pmatrix} \Sigma_r & 0 \end{pmatrix} V^\top w \right)_{i=1}^r = (U^\top y)_{i=1}^r \right\} \\ &= \left\{ w \in \mathbb{R}^n \mid (V^\top w)_{i=1}^r = \Sigma_r^{-1} (U^\top y)_{i=1}^r \right\} \\ &= \left\{ Vz \mid z \in \mathbb{R}^n, (z)_{i=1}^r = \Sigma_r^{-1} (U^\top y)_{i=1}^r \right\}, \end{aligned}$$

其中  $(a)_{i=1}^r$  表示向量  $a$  的前  $r$  个分量, 最后一个等号使用了  $V \in \mathbb{R}^{n \times n}$  的正交性. 由于  $\|Vz\| = \|z\|$ , 令  $z$  的第  $r+1, \dots, m$  个分量为零即可得到唯一的最小范数解, 从而

$$w_* = V \begin{pmatrix} \Sigma_r^{-1} (U^\top y)_{i=1}^r \\ 0 \end{pmatrix} = V \Sigma^\dagger U^\top y = A^\dagger y.$$

证毕. □

## B.2 向量空间

**定义 B.3:** 设  $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$ . 若集合  $X$  满足下列条件, 则称其为一个 ( $\mathbb{K}$  上的) 向量空间:

1. 加法的性质: 对每个  $x, y \in X$ , 存在  $x + y \in X$ , 使得对所有  $z \in X$ ,

$$x + y = y + x \quad \text{且} \quad x + (y + z) = (x + y) + z.$$

此外, 存在唯一元素  $0 \in X$ , 使得对所有  $x \in X$  都有  $x + 0 = x$ ; 并且对每个  $x \in X$ , 存在唯一的  $-x \in X$ , 使得  $x + (-x) = 0$ .

2. 标量乘法的性质: 存在一个从  $\mathbb{K} \times X$  到  $X$  的映射  $(\alpha, x) \mapsto \alpha x$ , 称为标量乘法. 对所有  $x \in X$ , 它满足  $1x = x$ ; 对所有  $\alpha, \beta \in \mathbb{K}$  及  $x \in X$ , 它满足  $(\alpha\beta)x = \alpha(\beta x)$ .

向量空间的元素称为**向量**.

若由语境可以明确所用域, 则简称  $X$  为向量空间. 本书主要考虑  $\mathbb{K} = \mathbb{R}$  的情形, 此时也称  $X$  为实向量空间.

为了在向量空间  $X$  上引入收敛概念, 需要为其配备一个拓扑, 见定义 A.2. **拓扑向量空间**是同时为拓扑空间, 并且其加法和标量乘法均为连续映射的向量空间. 下面讨论最重要的几类拓扑向量空间.

### B.2.1 度量空间

一类重要的拓扑向量空间由同时也是度量空间的向量空间构成.

**定义 B.4:** 对集合  $X$ , 若映射  $d_X: X \times X \rightarrow [0, \infty)$  满足

1.  $d_X(x, y) = 0$  当且仅当  $x = y$ ;
2. 对所有  $x, y \in X$ , 有  $d_X(x, y) = d_X(y, x)$ ;
3. 对所有  $x, y, z \in X$ , 有  $d_X(x, z) \leq d_X(x, y) + d_X(y, z)$ ,

则称其为一个**度量**, 并称  $(X, d_X)$  为**度量空间**.

在度量空间  $(X, d_X)$  中, 以

$$B_r(x) := \{y \in X \mid d_X(x, y) < r\} \quad (\text{B.2.1})$$

表示以  $x$  为中心、半径为  $r > 0$  的**开球**. 每个度量空间都自然配备一个拓扑: 集合  $A \subseteq X$  为开集, 当且仅当对每个  $x \in A$ , 都存在  $\varepsilon > 0$  使得  $B_\varepsilon(x) \subseteq A$ . 因而, 每个度量向量空间都是拓扑向量空间.

**定义 B.5:** 若关于  $d$  的每个 Cauchy 序列都收敛于  $X$  中的某个元素, 则称度量空间  $(X, d_X)$  **完备**.

对完备度量空间, Baire 纲定理是极为有力的工具. 为陈述它, 需要集合稠密性的概念. 设  $X$  是拓扑空间,  $A, B \subseteq X$ . 若  $A$  的闭包 (记作  $\overline{A}$ ) 满足  $\overline{A} \supseteq B$ , 则称  $A$  在  $B$  中**稠密**.

**定理 B.6** (Baire 纲定理): 设  $X$  是完备度量空间. 那么,  $X$  的任意可数族稠密开子集之交仍在  $X$  中稠密.

定理 B.6 蕴含: 若对某个集合序列  $(V_i)_{i \in \mathbb{N}}$  有  $X = \bigcup_{i=1}^{\infty} V_i$ , 则至少有一个  $V_i$  必须包含开集. 事实上, 假设所有  $V_i$  的内部均为空, 就意味着对所有  $i \in \mathbb{N}$ ,  $V_i^c = X \setminus V_i$  都是稠密的. 根据 De Morgan 律, 便有  $\emptyset = \bigcap_{i=1}^{\infty} V_i^c$ , 这与定理 B.6 矛盾.

### B.2.2 赋范空间

范数是为向量指定长度的一种方式. 赋范空间是配备了范数的向量空间.

**定义 B.7:** 设  $X$  是域  $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$  上的向量空间. 若映射  $\|\cdot\|_X: X \rightarrow [0, \infty)$  对所有  $x, y \in X$  以及所有  $\alpha \in \mathbb{K}$  都满足:

1. **三角不等式:**  $\|x + y\|_X \leq \|x\|_X + \|y\|_X$ ;
2. **绝对齐次性:**  $\|\alpha x\|_X = |\alpha| \|x\|_X$ ;
3. **正定性:**  $\|x\|_X = 0$  当且仅当  $x = 0$ ,

则称其为一个**范数**. 称  $(X, \|\cdot\|_X)$  为**赋范空间**; 若由语境可以明确范数, 则在记号中省略  $\|\cdot\|_X$ .

每个范数都通过  $d_X(x, y) := \|x - y\|_X$  诱导一个度量  $d_X$ , 进而诱导一个拓扑. 特别地, 每个赋范向量空间关于这一拓扑都是拓扑向量空间.

### B.2.3 Banach 空间

**定义 B.8:** 赋范向量空间是 **Banach 空间**, 当且仅当它完备.

在给出 Banach 空间的主要结果之前, 先汇集几个重要例子.

- *Euclidean* 空间: 设  $d \in \mathbb{N}$ . 那么  $(\mathbb{R}^d, \|\cdot\|)$  是 Banach 空间.
- 连续函数: 设  $d \in \mathbb{N}$ , 并设  $K \subseteq \mathbb{R}^d$  紧. 从  $K$  到  $\mathbb{R}$  的连续函数集合记作  $C(K)$ . 对  $\alpha, \beta \in \mathbb{R}, f, g \in C(K)$ , 逐点定义加法和标量乘法, 即对所有  $\mathbf{x} \in K, (\alpha f + \beta g)(\mathbf{x}) = \alpha f(\mathbf{x}) + \beta g(\mathbf{x})$ . 为向量空间  $C(K)$  配备上**确界范数**

$$\|f\|_\infty := \sup_{\mathbf{x} \in K} |f(\mathbf{x})|,$$

则它是 Banach 空间.

- *Lebesgue* 空间: 设  $(\Omega, \mathfrak{A}, \mu)$  是测度空间, 并设  $1 \leq p < \infty$ . **Lebesgue 空间**  $L^p(\Omega, \mu)$  定义为满足下式的可测函数  $f: \Omega \rightarrow \mathbb{R}$  关于  $\mu$ -几乎处处相等关系所得的等价类全体构成的向量空间:

$$\|f\|_{L^p(\Omega, \mu)} := \left( \int_{\Omega} |f(x)|^p d\mu(x) \right)^{1/p} < \infty. \quad (\text{B.2.2})$$

该积分与  $f$  的等价类代表元的选择无关. 加法和标量乘法与  $C(K)$  中一样逐点定义. 于是  $L^p(\Omega, \mu)$  是 Banach 空间. 若对  $d \in \mathbb{N}$ ,  $\Omega$  是  $\mathbb{R}^d$  的可测子集, 且  $\mu$  是 Lebesgue 测度, 则通常在记号中省略  $\mu$ , 简写为  $L^p(\Omega)$ . 若  $\Omega = \mathbb{N}$  且所用测度为计数测度, 则把这些空间记作  $\ell^p(\mathbb{N})$ , 或简称  $\ell^p$ .

这一定义可以推广到复值函数或  $\mathbb{R}^d$ -值函数. 对后一种情形, 把式 (B.2.2) 中的被积函数替换为  $\|f(x)\|^p$ . 仍以  $L^p(\Omega, \mu)$  表示这些空间, 其确切含义由语境确定.

- 本质有界函数: 设  $(\Omega, \mathfrak{A}, \mu)$  是测度空间. 通过定义  $L^\infty$ -范数

$$\|f\|_{L^\infty(\Omega, \mu)} := \inf\{C \geq 0 \mid \mu(\{|f| > C\}) = 0\},$$

可以把  $L^p$  空间推广到  $p = \infty$ . 在由从  $\Omega$  到  $\mathbb{R}$ 、关于  $\mu$ -几乎处处相等的可测函数之等价类构成的空间上, 这确实是一个范数. 此外,  $L^\infty(\Omega, \mu)$  关于这一范数是 Banach 空间. 若  $\Omega = \mathbb{N}$  且  $\mu$  是计数测度, 则把所得空间记作  $\ell^\infty(\mathbb{N})$ , 或简称  $\ell^\infty$ . 与  $p < \infty$  的情形一样, 可以直接把定义推广到复值函数或  $\mathbb{R}^d$ -值函数, 并仍使用同一记号.

下面引入对偶空间的概念.

**定义 B.9:** 设  $(X, \|\cdot\|_X)$  是域  $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$  上的赋范向量空间. 从  $X$  到  $\mathbb{K}$  的线性映射称为**线性泛函**.  $X$  上所有连续线性泛函构成的向量空间称为  $X$  的**(拓扑)对偶空间**, 记作  $X'$ .



配备自然的加法和标量乘法, 即对所有  $h, g \in X'$ 、 $\alpha \in \mathbb{K}$  及  $x \in X$ ,

$$(h + g)(x) := h(x) + g(x), \quad (\alpha h)(x) := \alpha(h(x)),$$

$X'$  是向量空间. 为  $X'$  配备范数

$$\|f\|_{X'} := \sup_{\substack{x \in X \\ \|x\|_X = 1}} |f(x)|.$$

即使  $(X, \|\cdot\|_X)$  不完备, 空间  $(X', \|\cdot\|_{X'})$  也总是 Banach 空间 [265, 定理 4.1].

对偶空间常可用于刻画原 Banach 空间. 对偶空间  $X'$  通过 Hahn–Banach 定理捕捉 Banach 空间  $X$  的某些代数和几何性质. 本书采用该定理的一个特定版本及其关于对偶基存在性的推论; 例如见文献 [265, 定理 3.5].

**定理 B.10** (几何 Hahn–Banach 定理, 子空间版本): 设  $M$  是 Banach 空间  $X$  的子空间, 并设  $x_0 \in X$ . 若  $x_0$  不属于  $M$  的闭包, 则存在  $f \in X'$ , 使得  $f(x_0) = 1$ , 且对每个  $x \in M$  都有  $f(x) = 0$ .

定理 B.10 的一个将在全书反复使用的直接推论, 是**对偶基**的存在性. 设  $X$  是 Banach 空间, 并设  $(x_i)_{i \in \mathbb{N}} \subseteq X$  满足: 对所有  $i \in \mathbb{N}$ ,

$$x_i \notin \overline{\text{span}\{x_j \mid j \in \mathbb{N}, j \neq i\}}.$$

那么, 对每个  $i \in \mathbb{N}$ , 都存在  $f_i \in X'$ , 使得当  $i \neq j$  时  $f_i(x_j) = 0$ , 并且  $f_i(x_i) = 1$ .

## B.2.4 Hilbert 空间

我们常常需要比赋范空间所提供的结构更多的结构. 内积通过引入角度与正交性的概念, 为比较向量提供了额外工具. 为简单起见, 下面只考虑实向量空间.

**定义 B.11:** 设  $X$  是实向量空间. 若映射  $\langle \cdot, \cdot \rangle_X: X \times X \rightarrow \mathbb{R}$  对所有  $x, y, z \in X$  以及所有  $\alpha, \beta \in \mathbb{R}$  都满足:

1. **线性性:**  $\langle \alpha x + \beta y, z \rangle_X = \alpha \langle x, z \rangle_X + \beta \langle y, z \rangle_X$ ;
2. **对称性:**  $\langle x, y \rangle_X = \langle y, x \rangle_X$ ;
3. **正定性:** 对所有  $x \neq 0$ , 都有  $\langle x, x \rangle_X > 0$ ,

则称其为  $X$  上的一个**内积**.

**例 B.12:** 当  $p = 2$  时, Lebesgue 空间  $L^2(\Omega)$  和  $\ell^2(\mathbb{N})$  都是 Hilbert 空间, 其内积分别为

$$\langle f, g \rangle_{L^2(\Omega)} = \int_{\Omega} f(x)g(x) \, dx \quad \text{对所有 } f, g \in L^2(\Omega),$$

以及

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\ell^2(\mathbb{N})} = \sum_{j \in \mathbb{N}} x_j y_j \quad \text{对所有 } \mathbf{x} = (x_j)_{j \in \mathbb{N}}, \mathbf{y} = (y_j)_{j \in \mathbb{N}} \in \ell^2(\mathbb{N}).$$

◇

在内积空间上, 成立所谓的 Cauchy-Schwarz 不等式.

**定理 B.13** (Cauchy-Schwarz 不等式): 设  $X$  是配备内积  $\langle \cdot, \cdot \rangle_X$  的向量空间. 那么, 对所有  $x, y \in X$ , 都有

$$|\langle x, y \rangle_X| \leq \sqrt{\langle x, x \rangle_X \langle y, y \rangle_X}.$$

此外, 等号成立当且仅当  $x$  与  $y$  线性相关.

**证明:** 设  $x, y \in X$ . 若  $y = 0$ , 则  $\langle x, y \rangle_X = 0$ , 所以结论显然成立. 以下设  $y \neq 0$ , 从而  $\langle y, y \rangle_X > 0$ . 利用线性性与对称性, 对所有  $\alpha \in \mathbb{R}$ , 都有

$$\begin{aligned} 0 &\leq \langle x - \alpha y, x - \alpha y \rangle_X \\ &= \langle x, x \rangle_X - 2\alpha \langle x, y \rangle_X + \alpha^2 \langle y, y \rangle_X. \end{aligned}$$

令  $\alpha := \langle x, y \rangle_X / \langle y, y \rangle_X$ , 得到

$$\begin{aligned} 0 &\leq \langle x, x \rangle_X - 2 \frac{\langle x, y \rangle_X^2}{\langle y, y \rangle_X} + \frac{\langle x, y \rangle_X^2}{\langle y, y \rangle_X} \\ &= \langle x, x \rangle_X - \frac{\langle x, y \rangle_X^2}{\langle y, y \rangle_X}. \end{aligned}$$

移项即得所需结论. □

每个内积  $\langle \cdot, \cdot \rangle_X$  都通过下式诱导一个范数:

$$\|x\|_X := \sqrt{\langle x, x \rangle} \quad \text{对所有 } x \in X. \quad (\text{B.2.3})$$

内积的性质立即给出**极化恒等式**

$$\|x + y\|_X^2 = \|x\|_X^2 + 2\langle x, y \rangle_X + \|y\|_X^2. \quad (\text{B.2.4})$$

式 (B.2.3) 确实定义了一个范数, 这可由对式 (B.2.4) 应用 Cauchy-Schwarz 不等式得到, 因为这说明  $\|\cdot\|_X$  满足三角不等式. 由此得到 Hilbert 空间的定义.

**定义 B.14:** 设  $H$  是配备内积  $\langle \cdot, \cdot \rangle_H$  的实向量空间. 当且仅当  $H$  关于内积诱导的范数  $\|\cdot\|_H$  完备时, 称  $(H, \langle \cdot, \cdot \rangle_H)$  为 **Hilbert 空间**.

Hilbert 空间的一个标准例子是  $L^2$ : 设  $(\Omega, \mathfrak{A}, \mu)$  是测度空间. 那么,

$$\langle f, g \rangle_{L^2(\Omega, \mu)} = \int_{\Omega} f(x)g(x) d\mu(x) \quad \text{对所有 } f, g \in L^2(\Omega, \mu),$$

定义了  $L^2(\Omega, \mu)$  上与  $L^2(\Omega, \mu)$ -范数相容的一个内积.

在 Hilbert 空间中, 不仅可以通过由范数测量的距离比较向量, 还可以利用反映向量相对方向的内积来比较向量. 这就引出了正交性的概念.

**定义 B.15:** 设  $(H, \langle \cdot, \cdot \rangle_H)$  是 Hilbert 空间, 并设  $f, g \in H$ . 若  $\langle f, g \rangle_H = 0$ , 则称  $f$  与  $g$  **正交**, 记作  $f \perp g$ . 对  $F, G \subseteq H$ , 若对所有  $f \in F, g \in G$  都有  $f \perp g$ , 则记作  $F \perp G$ . 最后, 对  $F \subseteq H$ , 集合  $F^\perp = \{g \in H \mid g \perp f \forall f \in F\}$  称为  $F$  在  $H$  中的**正交补**.

对正交向量，极化恒等式立即蕴含 Pythagorean 定理.

**定理 B.16** (Pythagorean 定理): 设  $(H, \langle \cdot, \cdot \rangle_H)$  是 Hilbert 空间,  $n \in \mathbb{N}$ , 并设  $f_1, \dots, f_n \in H$  两两正交. 那么,

$$\left\| \sum_{i=1}^n f_i \right\|_H^2 = \sum_{i=1}^n \|f_i\|_H^2.$$

本书将用到的 Hilbert 空间的最后一个性质，是到凸集上的唯一**投影**的存在性. 例如，证明可见文献 [264, 定理 4.10].

**定理 B.17:** 设  $(H, \langle \cdot, \cdot \rangle_H)$  是 Hilbert 空间，并设  $K \neq \emptyset$  是  $H$  的闭凸子集. 那么，对所有  $h \in H$ ，都存在唯一的  $k_0 \in K$ ，使得

$$\|h - k_0\|_H = \inf\{\|h - k\|_H \mid k \in K\}.$$

## 参考文献

- [1] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Software available from tensorflow.org.
- [2] M. A. Aizerman, E. A. Braverman, and L. Rozonoer. Theoretical foundations of the potential function method in pattern recognition learning. In *Automation and Remote Control*, number 25 in Automation and Remote Control, pages 821–837, 1964.
- [3] R. Alaifari, G. S. Alberti, and T. Gauksson. Adef: an iterative algorithm to construct adversarial deformations. *arXiv preprint arXiv:1804.07729*, 2018.
- [4] S. Alberti, N. Dern, L. Thesing, and G. Kutyniok. Sumformer: Universal approximation for efficient transformers. In *Topological, Algebraic and Geometric Learning Workshops 2023*, pages 72–86. PMLR, 2023.
- [5] Z. Allen-Zhu, Y. Li, and Y. Liang. Learning and generalization in overparameterized neural networks, going beyond two layers. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [6] M. A. Alvarez, L. Rosasco, and N. D. Lawrence. *Kernels for Vector-Valued Functions: A Review*. 2012.
- [7] S.-i. Amari. Natural gradient works efficiently in learning. *Neural Computation*, 10(2):251–276, 02 1998.
- [8] M. Anthony and P. L. Bartlett. *Neural network learning: theoretical foundations*. Cambridge University Press, Cambridge, 1999.
- [9] R. Arora, A. Basu, P. Mianjy, and A. Mukherjee. Understanding deep neural networks with rectified linear units. In *International Conference on Learning Representations*, 2018.
- [10] S. Arora, S. S. Du, W. Hu, Z. Li, R. R. Salakhutdinov, and R. Wang. On exact computation with an infinitely wide neural net. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.

- [11] S. Arora, R. Ge, B. Neyshabur, and Y. Zhang. Stronger generalization bounds for deep nets via a compression approach. In *International Conference on Machine Learning*, pages 254–263. PMLR, 2018.
- [12] J. L. Ba, J. R. Kiros, and G. E. Hinton. Layer normalization, 2016.
- [13] M. Baader, M. Mirman, and M. Vechev. Universal approximation with certified networks. *arXiv preprint arXiv:1909.13846*, 2019.
- [14] F. Bach. *Learning Theory from First Principles*. The MIT Press, 2025.
- [15] S. Barocas, M. Hardt, and A. Narayanan. *Fairness and Machine Learning*. fairml-book.org, 2019. <http://www.fairmlbook.org>.
- [16] A. R. Barron. Neural net approximation. In *Proc. 7th Yale workshop on adaptive and learning systems*, volume 1, pages 69–72, 1992.
- [17] A. R. Barron. Universal approximation bounds for superpositions of a sigmoidal function. *IEEE Trans. Inform. Theory*, 39(3):930–945, 1993.
- [18] A. R. Barron. Approximation and estimation bounds for artificial neural networks. *Machine learning*, 14(1):115–133, 1994.
- [19] A. R. Barron and J. M. Klusowski. Approximation and estimation for high-dimensional deep learning networks. *arXiv preprint arXiv:1809.03090*, 2018.
- [20] P. Bartlett. For valid generalization the size of the weights is more important than the size of the network. *Advances in neural information processing systems*, 9, 1996.
- [21] D. Beaglehole, M. Belkin, and P. Pandit. On the inconsistency of kernel ridgeless regression in fixed dimensions. *SIAM J. Math. Data Sci.*, 5(4):854–872, 2023.
- [22] A. Beck. *First-Order Methods in Optimization*. Society for Industrial and Applied Mathematics, Philadelphia, PA, 2017.
- [23] G. Beliakov. Interpolation of lipschitz functions. *Journal of Computational and Applied Mathematics*, 196(1):20–44, 2006.
- [24] M. Belkin, D. Hsu, S. Ma, and S. Mandal. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32):15849–15854, 2019.
- [25] M. Belkin, S. Ma, and S. Mandal. To understand deep learning we need to understand kernel learning. In *International Conference on Machine Learning*, pages 541–549. PMLR, 2018.

- [26] R. Bellman. On the theory of dynamic programming. *Proceedings of the national Academy of Sciences*, 38(8):716–719, 1952.
- [27] A. Ben-Israel and A. Charnes. Contributions to the theory of generalized inverses. *Journal of the Society for Industrial and Applied Mathematics*, 11(3):667–699, 1963.
- [28] A. Ben-Tal and A. Nemirovski. *Lectures on modern convex optimization*. MPS/SIAM Series on Optimization. Society for Industrial and Applied Mathematics (SIAM), Philadelphia, PA; Mathematical Programming Society (MPS), Philadelphia, PA, 2001. Analysis, algorithms, and engineering applications.
- [29] Y. Bengio, P. Simard, and P. Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166, 1994.
- [30] A. Berlinet and C. Thomas-Agnan. *Reproducing kernel Hilbert spaces in probability and statistics*. Kluwer Academic Publishers, Boston, MA, 2004. With a preface by Persi Diaconis.
- [31] L. Berlyand and P. Jabin. *Mathematics of Deep Learning: An Introduction*. De Gruyter Textbook. De Gruyter, 2023.
- [32] J. Berner, P. Grohs, and A. Jentzen. Analysis of the generalization error: Empirical risk minimization over deep artificial neural networks overcomes the curse of dimensionality in the numerical approximation of black–scholes partial differential equations. *SIAM Journal on Mathematics of Data Science*, 2(3):631–657, 2020.
- [33] J. Berner, P. Grohs, G. Kutyniok, and P. Petersen. The modern mathematics of deep learning, 2021.
- [34] D. P. Bertsekas. *Nonlinear programming*. Athena Scientific Optimization and Computation Series. Athena Scientific, Belmont, MA, third edition, 2016.
- [35] D. P. Bertsekas and J. N. Tsitsiklis. *Neuro-dynamic programming.*, volume 3 of *Optimization and neural computation series*. Athena Scientific, 1996.
- [36] C. M. Bishop. *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer, 1 edition, 2007.
- [37] Å. Björck. *Numerical Methods for Least Squares Problems*. Society for Industrial and Applied Mathematics, 1996.
- [38] H. Bölcskei, P. Grohs, G. Kutyniok, and P. Petersen. Optimal approximation with sparsely connected deep neural networks. *SIAM Journal on Mathematics of Data Science*, 1(1):8–45, 2019.

- [39] K. Borsuk. Drei sätze über die  $n$ -dimensionale euklidische sphäre. *Fundamenta Mathematicae*, 20(1):177–190, 1933.
- [40] B. E. Boser, I. M. Guyon, and V. N. Vapnik. A training algorithm for optimal margin classifiers. In D. Haussler, editor, *Proceedings of the 5th Annual Workshop on Computational Learning Theory (COLT'92)*, pages 144–152, Pittsburgh, PA, USA, July 1992. ACM Press.
- [41] L. Bottou. *Stochastic Gradient Descent Tricks*, pages 421–436. Springer Berlin Heidelberg, Berlin, Heidelberg, 2012.
- [42] L. Bottou, F. E. Curtis, and J. Nocedal. Optimization methods for large-scale machine learning. *SIAM Review*, 60(2):223–311, 2018.
- [43] O. Bousquet and A. Elisseeff. Stability and generalization. *The Journal of Machine Learning Research*, 2:499–526, 2002.
- [44] S. Boyd and L. Vandenberghe. *Convex optimization*. Cambridge University Press, Cambridge, 2004.
- [45] S. Boyd, L. Xiao, and A. Mutapcic. Subgradient methods. [https://web.stanford.edu/class/ee392o/subgrad\\_method.pdf](https://web.stanford.edu/class/ee392o/subgrad_method.pdf), 2003. Lecture Notes, Stanford University.
- [46] J. Braun and M. Griebel. On a constructive proof of kolmogorov’s superposition theorem. *Constructive Approximation*, 30(3):653–675, Dec 2009.
- [47] S. Brenner and R. Scott. *The Mathematical Theory of Finite Element Methods*. Texts in Applied Mathematics. Springer New York, 2007.
- [48] M. M. Bronstein, J. Bruna, T. Cohen, and P. Veličković. Geometric deep learning: Grids, groups, graphs, geodesics, and gauges. *arXiv preprint arXiv:2104.13478*, 2021.
- [49] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [50] S. Bubeck. Convex optimization: Algorithms and complexity. *Found. Trends Mach. Learn.*, 8:231–357, 2014.
- [51] S. Budzinskiy, W. Fang, L. Zeng, and P. Petersen. Numerical error analysis of large language models. *arXiv preprint arXiv:2503.10251*, 2025.
- [52] O. Calin. *Deep learning architectures*. Springer, 2020.
- [53] E. J. Candes. *Ridgelets: theory and applications*. Stanford University, 1998.



- [54] C. Carathéodory. Über den variabilitätsbereich der fourier’ schen konstanten von positiven harmonischen funktionen. *Rendiconti del Circolo Matematico di Palermo (1884-1940)*, 32:193–217, 1911.
- [55] N. Carlini and D. Wagner. Towards evaluating the robustness of neural networks. In *2017 IEEE Symposium on Security and Privacy (SP)*, pages 39–57. Ieee, 2017.
- [56] S. M. Carroll and B. W. Dickinson. Construction of neural nets using the radon transform. *International 1989 Joint Conference on Neural Networks*, pages 607–611 vol.1, 1989.
- [57] P. Chaudhari, A. Choromanska, S. Soatto, Y. LeCun, C. Baldassi, C. Borgs, J. Chayes, L. Sagun, and R. Zecchina. Entropy-sgd: Biasing gradient descent into wide valleys. *Journal of Statistical Mechanics: Theory and Experiment*, 2019(12):124018, 2019.
- [58] M. Chen, H. Jiang, W. Liao, and T. Zhao. Efficient approximation of deep relu networks for functions on low dimensional manifolds. *Advances in neural information processing systems*, 32, 2019.
- [59] R. T. Chen, Y. Rubanova, J. Bettencourt, and D. K. Duvenaud. Neural ordinary differential equations. *Advances in neural information processing systems*, 31, 2018.
- [60] L. Chizat, E. Oyallon, and F. Bach. On lazy training in differentiable programming. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d’Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [61] Y. Cho and L. Saul. Kernel methods for deep learning. In Y. Bengio, D. Schuurmans, J. Lafferty, C. Williams, and A. Culotta, editors, *Advances in Neural Information Processing Systems*, volume 22. Curran Associates, Inc., 2009.
- [62] F. Chollet. *Deep learning with Python*. Simon and Schuster, 2021.
- [63] A. Choromanska, M. Henaff, M. Mathieu, G. B. Arous, and Y. LeCun. The loss surfaces of multilayer networks. In *Artificial intelligence and statistics*, pages 192–204. PMLR, 2015.
- [64] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann, et al. Palm: Scaling language modeling with pathways. *J Mach Learn Res*, 24(240):1–113, 2023.
- [65] C. K. Chui and H. N. Mhaskar. Deep nets for local manifold learning. *Frontiers in Applied Mathematics and Statistics*, 4:12, 2018.

- [66] P. Ciarlet. *The Finite Element Method for Elliptic Problems*. Studies in Mathematics and its Applications. North Holland, 1978.
- [67] T. Cohen and M. Welling. Group equivariant convolutional networks. In *International conference on machine learning*, pages 2990–2999. PMLR, 2016.
- [68] J. B. Conway. *A course in functional analysis*, volume 96. Springer, 2019.
- [69] C. Cortes and V. Vapnik. Support vector networks. *Machine Learning*, 20:273–297, 1995.
- [70] N. Cristianini and J. Shawe-Taylor. *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press, 1 edition, 2000.
- [71] F. Cucker and S. Smale. On the mathematical foundations of learning. *Bulletin of the American mathematical society*, 39(1):1–49, 2002.
- [72] G. Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.
- [73] Y. N. Dauphin, R. Pascanu, C. Gulcehre, K. Cho, S. Ganguli, and Y. Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. *Advances in neural information processing systems*, 27, 2014.
- [74] A. G. de G. Matthews. Sample-then-optimize posterior sampling for bayesian linear models. 2017.
- [75] A. G. de G. Matthews, J. Hron, M. Rowland, R. E. Turner, and Z. Ghahramani. Gaussian process behaviour in wide deep neural networks. In *International Conference on Learning Representations*, 2018.
- [76] T. De Ryck, S. Lanthaler, and S. Mishra. On the approximation of functions by tanh neural networks. *Neural Networks*, 143:732–750, 2021.
- [77] A. Défossez, L. Bottou, F. R. Bach, and N. Usunier. A simple convergence proof of adam and adagrad. *Trans. Mach. Learn. Res.*, 2022, 2022.
- [78] J. W. Demmel. *Applied Numerical Linear Algebra*. SIAM, Jan. 1997.
- [79] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.
- [80] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *NAACL-HLT*, pages 4171–4186, 2019.

- [81] R. DeVore and G. Lorentz. *Constructive Approximation*. Grundlehren der mathematischen Wissenschaften. Springer Berlin Heidelberg, 1993.
- [82] R. A. DeVore. Nonlinear approximation. *Acta numerica*, 7:51–150, 1998.
- [83] L. Dinh, R. Pascanu, S. Bengio, and Y. Bengio. Sharp minima can generalize for deep nets. In *International Conference on Machine Learning*, pages 1019–1028. PMLR, 2017.
- [84] F. Draxler, K. Veschgini, M. Salmhofer, and F. Hamprecht. Essentially no barriers in neural network energy landscape. In *International conference on machine learning*, pages 1309–1318. PMLR, 2018.
- [85] M. Du, F. Yang, N. Zou, and X. Hu. Fairness in deep learning: A computational perspective. *IEEE Intelligent Systems*, 36(4):25–34, 2021.
- [86] S. Du, J. Lee, H. Li, L. Wang, and X. Zhai. Gradient descent finds global minima of deep neural networks. In K. Chaudhuri and R. Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 1675–1685. PMLR, 09–15 Jun 2019.
- [87] J. Duchi, E. Hazan, and Y. Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12(Jul):2121–2159, 2011.
- [88] W. E and Q. Wang. Exponential convergence of the deep neural network approximation for analytic functions. *Sci. China Math.*, 61(10):1733–1740, 2018.
- [89] K. Eckle and J. Schmidt-Hieber. A comparison of deep networks with relu activation function and linear spline-type methods. *Neural Networks*, 110:232–242, 2019.
- [90] D. Elbrächter, D. Perekrestenko, P. Grohs, and H. Bölcskei. Deep neural network approximation theory. *IEEE Transactions on Information Theory*, 67(5):2581–2623, 2021.
- [91] R. Eldan and O. Shamir. The power of depth for feedforward neural networks. In V. Feldman, A. Rakhlin, and O. Shamir, editors, *29th Annual Conference on Learning Theory*, volume 49 of *Proceedings of Machine Learning Research*, pages 907–940, Columbia University, New York, New York, USA, 23–26 Jun 2016. PMLR.
- [92] H. Engl, M. Hanke, and A. Neubauer. *Regularization of Inverse Problems*. Mathematics and Its Applications. Springer Netherlands, 2000.

- [93] A. Ern and J. Guermond. *Finite Elements I: Approximation and Interpolation*. Texts in Applied Mathematics. Springer International Publishing, 2021.
- [94] L. C. Evans. *Partial differential equations*, volume 19 of *Graduate Studies in Mathematics*. American Mathematical Society, Providence, RI, second edition, 2010.
- [95] M. Fischer, M. Balunovic, D. Drachsler-Cohen, T. Gehr, C. Zhang, and M. Vechev. DL2: training and querying neural networks with logic. In *International Conference on Machine Learning*, pages 1931–1941. PMLR, 2019.
- [96] C. L. Frenzen, T. Sasao, and J. T. Butler. On the number of segments needed in a piecewise linear approximation. *Journal of Computational and Applied mathematics*, 234(2):437–446, 2010.
- [97] K.-I. Funahashi. On the approximate realization of continuous mappings by neural networks. *Neural Networks*, 2(3):183–192, 1989.
- [98] T. Furuya, M. V. de Hoop, and G. Peyré. Transformers are universal in-context learners. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [99] T. Garipov, P. Izmailov, D. Podoprikin, D. P. Vetrov, and A. G. Wilson. Loss surfaces, mode connectivity, and fast ensembling of dnns. *Advances in neural information processing systems*, 31, 2018.
- [100] G. Garrigos and R. M. Gower. Handbook of convergence theorems for (stochastic) gradient methods, 2023.
- [101] T. Gehr, M. Mirman, D. Drachsler-Cohen, P. Tsankov, S. Chaudhuri, and M. Vechev. Ai2: Safety and robustness certification of neural networks with abstract interpretation. In *2018 IEEE symposium on security and privacy (SP)*, pages 3–18. IEEE, 2018.
- [102] A. Géron. *Hands-on machine learning with Scikit-Learn and TensorFlow : concepts, tools, and techniques to build intelligent systems*. O’Reilly Media, Sebastopol, CA, 2017.
- [103] B. Geshkovski, C. Letrouit, Y. Polyanskiy, and P. Rigollet. A mathematical perspective on transformers. *Bull. Amer. Math. Soc. (N.S.)*, 62(3):427–479, 2025.
- [104] F. Girosi and T. Poggio. Representation properties of networks: Kolmogorov’s theorem is irrelevant. *Neural Computation*, 1(4):465–469, 1989.
- [105] F. Girosi and T. Poggio. Networks and the best approximation property. *Biological cybernetics*, 63(3):169–176, 1990.

- [106] X. Glorot and Y. Bengio. Understanding the difficulty of training deep feedforward neural networks. In Y. W. Teh and M. Titterton, editors, *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, volume 9 of *Proceedings of Machine Learning Research*, pages 249–256, Chia Laguna Resort, Sardinia, Italy, 13–15 May 2010. PMLR.
- [107] G. Goh. Why momentum really works. *Distill*, 2017. <http://distill.pub/2017/momentum>.
- [108] G. H. Golub and C. F. Van Loan. *Matrix Computations - 4th Edition*. Johns Hopkins University Press, Philadelphia, PA, 2013.
- [109] L. Gonon and C. Schwab. Deep relu network expression rates for option prices in high-dimensional, exponential lévy models. *Finance and Stochastics*, 25(4):615–657, 2021.
- [110] I. J. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, Cambridge, MA, USA, 2016. <http://www.deeplearningbook.org>.
- [111] I. J. Goodfellow, J. Shlens, and C. Szegedy. Explaining and harnessing adversarial examples. In *International Conference on Learning Representations (ICLR)*, 2015.
- [112] I. J. Goodfellow, O. Vinyals, and A. M. Saxe. Qualitatively characterizing neural network optimization problems. *arXiv preprint arXiv:1412.6544*, 2014.
- [113] L.-A. Gottlieb, A. Kontorovich, and R. Krauthgamer. Efficient regression in metric spaces via approximate lipschitz extension. *IEEE Transactions on Information Theory*, 63(8):4838–4849, 2017.
- [114] R. M. Gower, N. Loizou, X. Qian, A. Sailanbayev, E. Shulgin, and P. Richtárik. SGD: General analysis and improved rates. In K. Chaudhuri and R. Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 5200–5209. PMLR, 09–15 Jun 2019.
- [115] K. Gröchenig. *Foundations of time-frequency analysis*. Springer Science & Business Media, 2013.
- [116] P. Grohs and L. Herrmann. Deep neural network approximation for high-dimensional elliptic pdes with boundary conditions. *IMA Journal of Numerical Analysis*, 42(3):2055–2082, 2022.
- [117] P. Grohs, F. Hornung, A. Jentzen, and P. Von Wurstemberger. *A proof that artificial neural networks overcome the curse of dimensionality in the numerical approximation of Black–Scholes partial differential equations*, volume 284. American Mathematical Society, 2023.

- [118] I. Gühring and M. Raslan. Approximation rates for neural networks with encodable weights in smoothness spaces. *Neural Networks*, 134:107–130, 2021.
- [119] E. Gumaan. Universal approximation theorem for a single-layer transformer, 2025.
- [120] E. Haber and L. Ruthotto. Stable architectures for deep neural networks. *Inverse problems*, 34(1):014004, 2017.
- [121] B. Hanin and D. Rolnick. Complexity of linear regions in deep networks. In *International Conference on Machine Learning*, pages 2596–2604. PMLR, 2019.
- [122] M. Hardt, B. Recht, and Y. Singer. Train faster, generalize better: Stability of stochastic gradient descent. In M. F. Balcan and K. Q. Weinberger, editors, *Proceedings of The 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pages 1225–1234, New York, New York, USA, 20–22 Jun 2016. PMLR.
- [123] T. Hastie, A. Montanari, S. Rosset, and R. J. Tibshirani. Surprises in high-dimensional ridgeless least squares interpolation. *The Annals of Statistics*, 50(2):949–986, 2022.
- [124] T. Hastie, R. Tibshirani, and J. Friedman. *The elements of statistical learning: data mining, inference and prediction*. Springer, 2 edition, 2009.
- [125] S. S. Haykin. *Neural networks and learning machines*. Pearson Education, Upper Saddle River, NJ, third edition, 2009.
- [126] J. He, L. Li, J. Xu, and C. Zheng. Relu deep neural networks and linear finite elements. *J. Comput. Math.*, 38(3):502–527, 2020.
- [127] K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. *Proceedings of the IEEE international conference on computer vision*, 2015.
- [128] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [129] M. Hein and M. Andriushchenko. Formal guarantees on the robustness of a classifier against adversarial manipulation. *Advances in neural information processing systems*, 30, 2017.
- [130] H. Heuser. *Lehrbuch der Analysis. Teil 1*. Vieweg + Teubner, Wiesbaden, revised edition, 2009.

- [131] S. Hochreiter. Untersuchungen zu dynamischen neuronalen Netzen. Diploma thesis, Institut für Informatik, Lehrstuhl Prof. Brauer, Technische Universität München, 1991.
- [132] S. Hochreiter and J. Schmidhuber. Flat minima. *Neural computation*, 9(1):1–42, 1997.
- [133] S. Hochreiter and J. Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [134] A. E. Hoerl and R. W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12:55–67, 1970.
- [135] K. Hornik. Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257, 1991.
- [136] K. Hornik, M. Stinchcombe, and H. White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- [137] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE conference on computer vision and pattern recognition*, 1(2):3, 2017.
- [138] G.-B. Huang and H. A. Babri. Upper bounds on the number of hidden neurons in feedforward networks with arbitrary bounded nonlinear activation functions. *IEEE transactions on neural networks*, 9(1):224–229, 1998.
- [139] L. Huang, A. D. Joseph, B. Nelson, B. I. Rubinstein, and J. D. Tygar. Adversarial machine learning. In *Proceedings of the 4th ACM workshop on Security and artificial intelligence*, pages 43–58, 2011.
- [140] T. Huster, C.-Y. J. Chiang, and R. Chadha. Limitations of the lipschitz constant as a defense against adversarial examples. In *ECML PKDD 2018 Workshops: Nemesis 2018, UrbReas 2018, SoGood 2018, IWAISe 2018, and Green Data Mining 2018, Dublin, Ireland, September 10-14, 2018, Proceedings 18*, pages 16–29. Springer, 2019.
- [141] M. Hutzenthaler, A. Jentzen, T. Kruse, and T. A. Nguyen. A proof that rectified deep neural networks overcome the curse of dimensionality in the numerical approximation of semilinear heat equations. *SN partial differential equations and applications*, 1(2):10, 2020.
- [142] J. Håstad. *Computational limitations of small depth circuits*. PhD thesis, Massachusetts Institute of Technology, 1987. Ph.D. Thesis, Department of Mathematics.



- [143] D. J. Im, M. Tao, and K. Branson. An empirical analysis of deep network loss surfaces. 2016.
- [144] V. E. Ismailov. *Ridge functions and applications in neural networks*, volume 263. American Mathematical Society, 2021.
- [145] V. E. Ismailov. A three layer neural network can represent any multivariate function. *Journal of Mathematical Analysis and Applications*, 523(1):127096, 2023.
- [146] Y. Ito and K. Saito. Superposition of linearly independent functions and finite mappings by neural networks. *The Mathematical Scientist*, 21(1):27, 1996.
- [147] A. Jacot, F. Gabriel, and C. Hongler. Neural tangent kernel: Convergence and generalization in neural networks. *Advances in neural information processing systems*, 31, 2018.
- [148] A. Jentzen, B. Kuckuck, and P. von Wurstemberger. Mathematical introduction to deep learning: methods, implementations, and theory. *arXiv preprint arXiv:2310.20360*, 2023.
- [149] A. Jentzen and A. Riekert. On the existence of global minima and convergence analyses for gradient descent methods in the training of deep neural networks. *arXiv preprint arXiv:2112.09684*, 2021.
- [150] A. Jentzen, D. Salimova, and T. Welti. A proof that deep artificial neural networks overcome the curse of dimensionality in the numerical approximation of Kolmogorov partial differential equations with constant diffusion and nonlinear drift coefficients. *Commun. Math. Sci.*, 19(5):1167–1205, 2021.
- [151] Y. Jiang, B. Neyshabur, H. Mobahi, D. Krishnan, and S. Bengio. Fantastic generalization measures and where to find them. In *International Conference on Learning Representations (ICLR)*, 2019.
- [152] J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Žídek, A. Potapenko, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 596(7873):583–589, 2021.
- [153] P. C. Kainen, V. Kurkova, and A. Vogt. Approximation by neural networks is not continuous. *Neurocomputing*, 29(1-3):47–56, 1999.
- [154] P. C. Kainen, V. Kurkova, and A. Vogt. Continuity of approximation by neural networks in  $l_p$  spaces. *Annals of Operations Research*, 101:143–147, 2001.
- [155] P. C. Kainen, V. Kurkova, and A. Vogt. Best approximation by linear combinations of characteristic functions of half-spaces. *Journal of Approximation Theory*, 122(2):151–159, 2003.

- [156] H. Karimi, J. Nutini, and M. Schmidt. Linear convergence of gradient and proximal-gradient methods under the polyak-łojasiewicz condition. In P. Frasconi, N. Landwehr, G. Manco, and J. Vreeken, editors, *Machine Learning and Knowledge Discovery in Databases*, pages 795–811, Cham, 2016. Springer International Publishing.
- [157] C. Karner, V. Kazeev, and P. C. Petersen. Limitations of gradient descent due to numerical instability of backpropagation. *arXiv preprint arXiv:2210.00805*, 2022.
- [158] A. Katharopoulos, A. Vyas, N. Pappas, and F. Fleuret. Transformers are RNNs: Fast autoregressive transformers with linear attention. In H. D. III and A. Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 5156–5165. PMLR, 13–18 Jul 2020.
- [159] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy, and P. T. P. Tang. On large-batch training for deep learning: Generalization gap and sharp minima. *CoRR*, abs/1609.04836, 2016.
- [160] G. S. Kimeldorf and G. Wahba. A correspondence between bayesian estimation on stochastic processes and smoothing by splines. *The Annals of Mathematical Statistics*, 41(2):495–502, 1970.
- [161] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. In *3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings*. International Conference on Learning Representations, ICLR, 2015.
- [162] A. Klenke. *Wahrscheinlichkeitstheorie*. Springer, 2006.
- [163] M. Kohler, A. Krzyżak, and S. Langer. Estimation of a function of low local dimensionality by deep neural networks. *IEEE transactions on information theory*, 68(6):4032–4042, 2022.
- [164] M. Kohler and S. Langer. On the rate of convergence of fully connected deep neural network regression estimates. *The Annals of Statistics*, 49(4):2231–2249, 2021.
- [165] A. Kolmogoroff. Über die beste annäherung von funktionen einer gegebenen funktionenklasse. *Annals of Mathematics*, 37(1):107–110, 1936.
- [166] A. N. Kolmogorov. On the representation of continuous functions of many variables by superposition of continuous functions of one variable and addition. *Dokl. Akad. Nauk SSSR*, 114:953–956, 1957.

- [167] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012.
- [168] A. Krogh and J. Hertz. A simple weight decay can improve generalization. In J. Moody, S. Hanson, and R. Lippmann, editors, *Advances in Neural Information Processing Systems*, volume 4. Morgan-Kaufmann, 1991.
- [169] G. Kutyniok, P. Petersen, M. Raslan, and R. Schneider. A theoretical analysis of deep neural networks and parametric pdes. *Constructive Approximation*, 55(1):73–125, 2022.
- [170] V. Kůrková. Kolmogorov’s theorem is relevant. *Neural Computation*, 3(4):617–622, 1991.
- [171] V. Kůrková. Kolmogorov’s theorem and multilayer neural networks. *Neural Networks*, 5(3):501–506, 1992.
- [172] F. Laakmann and P. Petersen. Efficient approximation of solutions of parametric linear transport equations by relu dnns. *Advances in Computational Mathematics*, 47(1):11, 2021.
- [173] G. Lan. *First-order and Stochastic Optimization Methods for Machine Learning*. Springer Series in the Data Sciences. Springer International Publishing, Cham, 1st ed. 2020. edition, 2020.
- [174] Y. LeCun, Y. Bengio, and G. Hinton. Deep learning. *Nature*, 521(7553):436–444, May 2015.
- [175] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1(4):541–551, 1989.
- [176] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 2002.
- [177] Y. LeCun, L. Bottou, G. Orr, and K. Müller. Efficient backprop. In *Neural Networks: Tricks of the Trade*, Lecture Notes in Computer Science, chapter 2, page 546. Springer Berlin / Heidelberg, 1998.
- [178] J. Lee, J. Sohl-dickstein, J. Pennington, R. Novak, S. Schoenholz, and Y. Bahri. Deep neural networks as gaussian processes. In *International Conference on Learning Representations*, 2018.

- [179] J. Lee, L. Xiao, S. Schoenholz, Y. Bahri, R. Novak, J. Sohl-Dickstein, and J. Pennington. Wide neural networks of any depth evolve as linear models under gradient descent. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [180] M. Leshno, V. Y. Lin, A. Pinkus, and S. Schocken. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks*, 6(6):861–867, 1993.
- [181] L. Lessard, B. Recht, and A. Packard. Analysis and design of optimization algorithms via integral quadratic constraints. *SIAM J. Optim.*, 26(1):57–95, 2016.
- [182] H. Li, Z. Xu, G. Taylor, C. Studer, and T. Goldstein. Visualizing the loss landscape of neural nets. *Advances in neural information processing systems*, 31, 2018.
- [183] W. Li. Generalization error of minimum weighted norm and kernel interpolation. *SIAM Journal on Mathematics of Data Science*, 3(1):414–438, 2021.
- [184] S. Liang and R. Srikant. Why deep neural networks for function approximation? In *Proc. of ICLR 2017*, pages 1 – 17, 2017.
- [185] T. Liang and A. Rakhlin. Just interpolate: kernel “ridgeless” regression can generalize. *Ann. Statist.*, 48(3):1329–1347, 2020.
- [186] H. Lin and S. Jegelka. Resnet with one-neuron hidden layers is a universal approximator. *Advances in neural information processing systems*, 31, 2018.
- [187] V. Lin and A. Pinkus. Fundamentality of ridge functions. *Journal of Approximation Theory*, 75(3):295–311, 1993.
- [188] L. Liu, X. Liu, J. Gao, W. Chen, and J. Han. Understanding the difficulty of training transformers, 2020.
- [189] M. Longo, J. A. Opschoor, N. Disch, C. Schwab, and J. Zech. De rham compatible deep neural network fem. *Neural Networks*, 165:721–739, 2023.
- [190] C. Ma, S. Wojtowytsch, L. Wu, et al. Towards a mathematical understanding of neural network-based machine learning: what we know and what we don’t. *arXiv preprint arXiv:2009.10713*, 2020.
- [191] C. Ma, L. Wu, et al. A priori estimates of the population risk for two-layer neural networks. *arXiv preprint arXiv:1810.06397*, 2018.
- [192] S. Mahan, E. J. King, and A. Cloninger. Nonclosedness of sets of neural networks in sobolev spaces. *Neural Networks*, 137:85–96, 2021.

- [193] V. Maiorov and A. Pinkus. Lower bounds for approximation by mlp neural networks. *Neurocomputing*, 25(1):81–91, 1999.
- [194] S. Mallat. Group invariant scattering. *Communications on Pure and Applied Mathematics*, 65(10):1331–1398, 2012.
- [195] Y. Marzouk, Z. Ren, S. Wang, and J. Zech. Distribution learning via neural differential equations: a nonparametric statistical perspective. *Journal of Machine Learning Research (accepted)*, 2024.
- [196] W. S. McCulloch and W. Pitts. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5:115–133, 1943.
- [197] S. Mei and A. Montanari. The generalization error of random features regression: Precise asymptotics and the double descent curve. *Communications on Pure and Applied Mathematics*, 75(4):667–766, 2022.
- [198] H. N. Mhaskar. Approximation properties of a multilayered feedforward artificial neural network. *Adv. Comput. Math.*, 1(1):61–80, 1993.
- [199] H. N. Mhaskar. Neural networks for optimal approximation of smooth and analytic functions. *Neural computation*, 8(1):164–177, 1996.
- [200] H. N. Mhaskar and C. A. Micchelli. Approximation by superposition of sigmoidal and radial basis functions. *Adv. in Appl. Math.*, 13(3):350–373, 1992.
- [201] H. N. Mhaskar and C. A. Micchelli. Degree of approximation by neural and translation networks with a single hidden layer. *Advances in applied mathematics*, 16(2):151–183, 1995.
- [202] M. Mohri, A. Rostamizadeh, and A. Talwalkar. *Foundations of machine learning*. MIT press, 2018.
- [203] C. Molnar. *Interpretable machine learning*. Lulu. com, 2020.
- [204] H. Montanelli and Q. Du. New error bounds for deep relu networks using sparse grids. *SIAM Journal on Mathematics of Data Science*, 1(1):78–92, 2019.
- [205] H. Montanelli and H. Yang. Error bounds for deep relu networks using the kolmogorov–arnold superposition theorem. *Neural Networks*, 129:1–6, 2020.
- [206] G. F. Montufar, R. Pascanu, K. Cho, and Y. Bengio. On the number of linear regions of deep neural networks. In Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, and K. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 27. Curran Associates, Inc., 2014.

- [207] S.-M. Moosavi-Dezfooli, A. Fawzi, O. Fawzi, and P. Frossard. Universal adversarial perturbations. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1765–1773, 2017.
- [208] E. Moulines and F. Bach. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In J. Shawe-Taylor, R. Zemel, P. Bartlett, F. Pereira, and K. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 24. Curran Associates, Inc., 2011.
- [209] K. P. Murphy. *Probabilistic Machine Learning: An introduction*. MIT Press, 2022.
- [210] K. P. Murphy. *Probabilistic Machine Learning: Advanced Topics*. MIT Press, 2023.
- [211] R. Nakada and M. Imaizumi. Adaptive approximation and generalization of deep neural network with intrinsic dimensionality. *Journal of Machine Learning Research*, 21(174):1–38, 2020.
- [212] R. M. Neal. *Bayesian learning for neural networks*. PhD thesis, University of Toronto, 1995.
- [213] A. Nemirovski, A. Juditsky, G. Lan, and A. Shapiro. Robust stochastic approximation approach to stochastic programming. *SIAM Journal on Optimization*, 19(4):1574–1609, 2009.
- [214] Y. Nesterov. *Introductory lectures on convex optimization*, volume 87 of *Applied Optimization*. Kluwer Academic Publishers, Boston, MA, 2004. A basic course.
- [215] Y. Nesterov. *Lectures on convex optimization*, volume 137 of *Springer Optimization and Its Applications*. Springer, Cham, second edition, 2018.
- [216] Y. E. Nesterov. A method for solving the convex programming problem with convergence rate  $O(1/k^2)$ . *Dokl. Akad. Nauk SSSR*, 269(3):543–547, 1983.
- [217] B. Neyshabur, R. Tomioka, and N. Srebro. Norm-based capacity control in neural networks. In *Conference on learning theory*, pages 1376–1401. PMLR, 2015.
- [218] R. Nickl. Donsker-type theorems for nonparametric maximum likelihood estimators. *Probability Theory and Related Fields*, 138(3-4), 2007.
- [219] M. A. Nielsen. *Neural networks and deep learning*, 2018.
- [220] R. H. Nielsen. Kolmogorov’s mapping neural network existence theorem. In *Proceedings of the IEEE First International Conference on Neural Networks* (San Diego, CA), volume III, pages 11–13. Piscataway, NJ: IEEE, 1987.

- [221] J. Nocedal and S. J. Wright. *Numerical optimization*. Springer Series in Operations Research and Financial Engineering. Springer, New York, second edition, 2006.
- [222] E. Novak and H. Wozniakowski. *Tractability of Multivariate Problems, Volume 1: Linear Information*. European Mathematical Society, 2008.
- [223] E. Novak and H. Woźniakowski. Approximation of infinitely differentiable multivariate functions is intractable. *Journal of Complexity*, 25(4):398–404, 2009.
- [224] B. O’Donoghue and E. Candès. Adaptive restart for accelerated gradient schemes. *Found. Comput. Math.*, 15(3):715–732, 2015.
- [225] J. A. Opschoor. Constructive deep neural network approximations of weighted analytic solutions to partial differential equations in polygons, 2023. Dissertation 29278, ETH Zürich, <https://doi.org/10.3929/ethz-b-000614671>.
- [226] J. A. Opschoor and C. Schwab. Deep relu networks and high-order finite element methods ii: Chebyšev emulation. *Computers & Mathematics with Applications*, 169:142–162, 2024.
- [227] J. A. A. Opschoor, P. C. Petersen, and C. Schwab. Deep relu networks and high-order finite element methods. *Analysis and Applications*, 18(05):715–770, 2020.
- [228] J. A. A. Opschoor, C. Schwab, and J. Zech. Exponential ReLU DNN expression of holomorphic maps in high dimension. *Constructive Approximation*, 2021.
- [229] J. A. A. Opschoor, C. Schwab, and J. Zech. Deep learning in high dimension: ReLU neural network expression for Bayesian PDE inversion. In *Optimization and control for partial differential equations—uncertainty quantification, open and closed-loop control, and shape optimization*, volume 29 of *Radon Ser. Comput. Appl. Math.*, pages 419–462. De Gruyter, Berlin, 2022.
- [230] P. Oswald. On the degree of nonlinear spline approximation in Besov-Sobolev spaces. *J. Approx. Theory*, 61(2):131–157, 1990.
- [231] S. Ovchinnikov. Max-min representation of piecewise linear functions. *Beiträge Algebra Geom.*, 43(1):297–302, 2002.
- [232] N. Papernot, P. McDaniel, I. Goodfellow, S. Jha, Z. B. Celik, and A. Swami. Practical black-box attacks against machine learning. In *Proceedings of the 2017 ACM on Asia conference on computer and communications security*, pages 506–519, 2017.
- [233] Y. C. Pati and P. S. Krishnaprasad. Analysis and synthesis of feedforward neural networks using discrete affine wavelet transformations. *IEEE Transactions on Neural Networks*, 4(1):73–85, 1993.



- [234] J. Pennington and Y. Bahri. Geometry of neural network loss surfaces via random matrix theory. In *International Conference on Machine Learning*, pages 2798–2806. PMLR, 2017.
- [235] P. Petersen, M. Raslan, and F. Voigtlaender. Topological properties of the set of functions generated by neural networks of fixed size. *Foundations of computational mathematics*, 21:375–444, 2021.
- [236] P. Petersen and F. Voigtlaender. Optimal approximation of piecewise smooth functions using deep relu neural networks. *Neural Networks*, 108:296–330, 2018.
- [237] P. Petersen and F. Voigtlaender. Equivalence of approximation by convolutional neural networks and fully-connected networks. *Proceedings of the American Mathematical Society*, 148(4):1567–1581, 2020.
- [238] P. C. Petersen. *Neural Network Theory*. 2020. [http://www.pc-petersen.eu/Neural\\_Network\\_Theory.pdf](http://www.pc-petersen.eu/Neural_Network_Theory.pdf), Lecture notes.
- [239] M. D. Petković and P. S. Stanimirović. Iterative method for computing the moore–penrose inverse based on penrose equations. *Journal of Computational and Applied Mathematics*, 235(6):1604–1613, 2011.
- [240] A. Pinkus. Approximation theory of the MLP model in neural networks. In *Acta numerica, 1999*, volume 8 of *Acta Numer.*, pages 143–195. Cambridge Univ. Press, Cambridge, 1999.
- [241] A. Pinkus. *n-Widths in Approximation Theory*. Ergebnisse der Mathematik und ihrer Grenzgebiete. 3. Folge / A Series of Modern Surveys in Mathematics. Springer Berlin Heidelberg, 2012.
- [242] G. Pisier. Remarques sur un résultat non publié de B. Maurey. *Séminaire Analyse fonctionnelle (dit "Maurey-Schwartz")*, 1980-1981.
- [243] T. Poggio, A. Banburski, and Q. Liao. Theoretical issues in deep networks. *Proceedings of the National Academy of Sciences*, 117(48):30039–30045, 2020.
- [244] T. Poggio, H. Mhaskar, L. Rosasco, B. Miranda, and Q. Liao. Why and when can deep-but not shallow-networks avoid the curse of dimensionality: a review. *Int. J. Autom. Comput.*, 14(5):503–519, 2017.
- [245] T. Poggio, R. Rifkin, S. Mukherjee, and P. Niyogi. General conditions for predictivity in learning theory. *Nature*, 428(6981):419–422, 2004.
- [246] B. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.

- [247] B. T. Polyak. *Introduction to optimization*. Translations Series in Mathematics and Engineering. Optimization Software, Inc., Publications Division, New York, 1987. Translated from the Russian, With a foreword by Dimitri P. Bertsekas.
- [248] B. M. Pötscher and I. R. Prucha. *Dynamic nonlinear econometric models*. Springer-Verlag, Berlin, 1997. Asymptotic theory.
- [249] S. J. Prince. *Understanding Deep Learning*. MIT Press, 2023.
- [250] N. Qian. On the momentum term in gradient descent learning algorithms. *Neural Networks*, 12(1):145–151, 1999.
- [251] M. H. Quynh Nguyen, Mahesh Chandra Mukkamala. On the loss landscape of a class of deep neural networks with no bad local valleys. In *International Conference on Learning Representations (ICLR)*, 2018.
- [252] R. H. R. DeVore and C. Micchelli. Optimal nonlinear approximation. *Manuscripta mathematica*, 63(4):469–478, 1989.
- [253] M. Raghu, B. Poole, J. Kleinberg, S. Ganguli, and J. Sohl-Dickstein. On the expressive power of deep neural networks. In D. Precup and Y. W. Teh, editors, *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 2847–2854. PMLR, 06–11 Aug 2017.
- [254] A. Rahimi and B. Recht. Random features for large-scale kernel machines. In J. Platt, D. Koller, Y. Singer, and S. Roweis, editors, *Advances in Neural Information Processing Systems*, volume 20. Curran Associates, Inc., 2007.
- [255] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational physics*, 378:686–707, 2019.
- [256] A. Rakhlin, O. Shamir, and K. Sridharan. Making gradient descent optimal for strongly convex stochastic optimization. In *Proceedings of the 29th International Conference on Machine Learning*, ICML’12, page 1571–1578, Madison, WI, USA, 2012. Omnipress.
- [257] C. E. Rasmussen and C. K. I. Williams. *Gaussian processes for machine learning*. Adaptive computation and machine learning. MIT Press, 2006.
- [258] E. Real, S. Moore, A. Selle, S. Saxena, Y. L. Suematsu, Q. Le, and A. Kurakin. Regularized evolution for image classifier architecture search. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33:4780–4789, 2019.

- [259] S. J. Reddi, S. Kale, and S. Kumar. On the convergence of adam and beyond. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net, 2018.
- [260] H. Robbins and S. Monro. A Stochastic Approximation Method. *The Annals of Mathematical Statistics*, 22(3):400 – 407, 1951.
- [261] F. Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.
- [262] W. Ruan, X. Yi, and X. Huang. Adversarial robustness of deep learning: Theory, algorithms, and applications. In *Proceedings of the 30th ACM international conference on information & knowledge management*, pages 4866–4869, 2021.
- [263] S. Ruder. An overview of gradient descent optimization algorithms, 2016.
- [264] W. Rudin. *Real and complex analysis*. McGraw-Hill Book Co., New York, third edition, 1987.
- [265] W. Rudin. *Functional analysis*. International Series in Pure and Applied Mathematics. McGraw-Hill, Inc., New York, second edition, 1991.
- [266] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [267] T. D. Ryck and S. Mishra. Error analysis for deep neural network approximations of parametric hyperbolic conservation laws. *Mathematics of Computation*, 2023. Article electronically published on December 15, 2023.
- [268] I. Safran and O. Shamir. Depth separation in relu networks for approximating smooth non-linear functions. *ArXiv*, abs/1610.09887, 2016.
- [269] M. E. Sander, P. Ablin, M. Blondel, and G. Peyré. Sinkformers: Transformers with doubly stochastic attention. In G. Camps-Valls, F. J. R. Ruiz, and I. Valera, editors, *Proceedings of The 25th International Conference on Artificial Intelligence and Statistics*, volume 151 of *Proceedings of Machine Learning Research*, pages 3515–3530. PMLR, 28–30 Mar 2022.
- [270] M. E. Sander and G. Peyré. Towards understanding the universality of transformers for next-token prediction. *ArXiv*, abs/2410.03011, 2024.
- [271] M. A. Sartori and P. J. Antsaklis. A simple method to derive bounds on the size and to train multilayer neural networks. *IEEE transactions on neural networks*, 2(4):467–471, 1991.

- [272] R. Scheichl and J. Zech. Numerical methods for bayesian inverse problems, 2021. Lecture Notes.
- [273] J. Schmidhuber. Deep learning in neural networks: An overview. *Neural Networks*, 61:85–117, 2015.
- [274] A. J. Schmidt-Hieber. Nonparametric regression using deep neural networks with relu activation function. *Annals of statistics*, 48(4):1875–1897, 2020.
- [275] J. Schmidt-Hieber. Deep relu network approximation of functions on a manifold. *arXiv preprint arXiv:1908.00695*, 2019.
- [276] J. Schmidt-Hieber. The kolmogorov–arnold representation theorem revisited. *Neural Networks*, 137:119–126, 2021.
- [277] B. Schölkopf, R. Herbrich, and A. J. Smola. A generalized representer theorem. In *Proceedings of the Annual Conference on Learning Theory*, 2001.
- [278] B. Schölkopf and A. J. Smola. *Learning with kernels : support vector machines, regularization, optimization, and beyond*. Adaptive computation and machine learning. MIT Press, 2002.
- [279] L. Schumaker. *Spline Functions: Basic Theory*. Cambridge Mathematical Library. Cambridge University Press, 3 edition, 2007.
- [280] C. Schwab and J. Zech. Deep learning in high dimension: neural network expression rates for generalized polynomial chaos expansions in UQ. *Anal. Appl. (Singap.)*, 17(1):19–55, 2019.
- [281] C. Schwab and J. Zech. Deep learning in high dimension: neural network expression rates for analytic functions in  $L^2(\mathbb{R}^d, \gamma_d)$ . *SIAM/ASA J. Uncertain. Quantif.*, 11(1):199–234, 2023.
- [282] A. Seplarskaia, S. Langer, and J. Schmidt-Hieber. On the vc dimension of deep group convolutional neural networks. *arXiv preprint arXiv:2410.15800*, 2024.
- [283] T. Serra, C. Tjandraatmadja, and S. Ramalingam. Bounding and counting linear regions of deep neural networks, 2018.
- [284] U. Shaham, A. Cloninger, and R. R. Coifman. Provable approximation properties for deep neural networks. *Applied and Computational Harmonic Analysis*, 44(3):537–557, 2018.
- [285] S. Shalev-Shwartz and S. Ben-David. *Understanding Machine Learning - From Theory to Algorithms*. Cambridge University Press, 2014.

- [286] O. Shamir and T. Zhang. Stochastic gradient descent for non-smooth optimization: Convergence results and optimal averaging schemes. In S. Dasgupta and D. McAllester, editors, *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 71–79, Atlanta, Georgia, USA, 17–19 Jun 2013. PMLR.
- [287] N. Z. Shor. *Minimization Methods for Non-Differentiable Functions*, volume 3 of *Springer Series in Computational Mathematics*. Springer-Verlag, Berlin, Heidelberg, 1985.
- [288] J. W. Siegel and J. Xu. High-order approximation rates for shallow neural networks with cosine and reluk activation functions. *Applied and Computational Harmonic Analysis*, 58:1–26, 2022.
- [289] D. Silver, A. Huang, C. J. Maddison, A. Guez, L. Sifre, G. Van Den Driessche, J. Schrittwieser, I. Antonoglou, V. Panneershelvam, M. Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *nature*, 529(7587):484–489, 2016.
- [290] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2014.
- [291] D. Soudry, E. Hoffer, M. S. Nacson, S. Gunasekar, and N. Srebro. The implicit bias of gradient descent on separable data. *Journal of Machine Learning Research*, 19(70):1–57, 2018.
- [292] E. M. Stein. *Singular integrals and differentiability properties of functions*. Princeton Mathematical Series, No. 30. Princeton University Press, Princeton, N.J., 1970.
- [293] H. Steinlein. Borsuk’s antipodal theorem and its generalizations and applications: a survey. In *Topological methods in nonlinear analysis*, volume 95 of *Sém. Math. Sup.*, pages 166–235. Presses Univ. Montréal, Montreal, QC, 1985.
- [294] I. Steinwart and A. Christmann. *Support Vector Machines*. Springer, New York, 2008.
- [295] G. Strang. Lecture 23: Accelerating gradient descent (use momentum). MIT OpenCourseWare: Matrix Methods in Data Analysis, Signal Processing, And Machine Learning, 2018. <https://ocw.mit.edu/courses/18-065-matrix-methods-in-data-analysis-signal-processing-and-machine-learning-spring-2018/resources/lecture-23-accelerating-gradient-descent-use-momentum/>.

- [296] D. Stutz, M. Hein, and B. Schiele. Disentangling adversarial robustness and generalization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 6976–6987, 2019.
- [297] A. Sukharev. Optimal method of constructing best uniform approximations for functions of a certain class. *USSR Computational Mathematics and Mathematical Physics*, 18(2):21–31, 1978.
- [298] I. Sutskever, J. Martens, G. Dahl, and G. Hinton. On the importance of initialization and momentum in deep learning. In S. Dasgupta and D. McAllester, editors, *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 1139–1147, Atlanta, Georgia, USA, 17–19 Jun 2013. PMLR.
- [299] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1–9, 2015.
- [300] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus. Intriguing properties of neural networks. In *International Conference on Learning Representations (ICLR)*, 2014.
- [301] M. Tan and Q. V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, pages 6105–6114, 2019.
- [302] S. Taniguchi, K. Harada, G. Minegishi, Y. Oshima, S. C. Jeong, G. Nagahara, T. Iiyama, M. Suzuki, Y. Iwasawa, and Y. Matsuo. Adopt: Modified adam can converge with any  $\beta_2$  with the optimal rate, 2024.
- [303] J. Tarela and M. Martínez. Region configurations for realizability of lattice piecewise-linear models. *Mathematical and Computer Modelling*, 30(11):17–27, 1999.
- [304] J. M. Tarela, E. Alonso, and M. V. Martínez. A representation method for PWL functions oriented to parallel processing. *Math. Comput. Modelling*, 13(10):75–83, 1990.
- [305] M. Telgarsky. Representation benefits of deep feedforward networks, 2015.
- [306] M. Telgarsky. Benefits of depth in neural networks. In V. Feldman, A. Rakhlin, and O. Shamir, editors, *29th Annual Conference on Learning Theory*, volume 49 of *Proceedings of Machine Learning Research*, pages 1517–1539, Columbia University, New York, New York, USA, 23–26 Jun 2016. PMLR.

- [307] M. Telgarsky. Neural networks and rational functions. In D. Precup and Y. W. Teh, editors, *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 3387–3393. PMLR, 06–11 Aug 2017.
- [308] M. Telgarsky. Deep learning theory lecture notes. <https://mjt.cs.illinois.edu/dlt/>, 2021. Version: 2021-10-27 v0.0-e7150f2d (alpha).
- [309] T. Tieleman and G. Hinton. Lecture 6.5—RmsProp: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning, 2012. [http://www.cs.toronto.edu/~tijmen/csc321/slides/lecture\\_slides\\_lec6.pdf](http://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf).
- [310] V. M. Tikhomirov.  $\varepsilon$ -entropy and  $\varepsilon$ -capacity of sets in functional spaces. *Selected Works of AN Kolmogorov: Volume III: Information Theory and the Theory of Algorithms*, pages 86–170, 1993.
- [311] A. N. Tikhonov. Regularization of incorrectly posed problems. *Soviet Mathematics Doklady*, 4(6):1624–1627, 1963.
- [312] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, et al. Llama: Open and efficient foundation language models, 2023.
- [313] S. Tu, S. Venkataraman, A. C. Wilson, A. Gittens, M. I. Jordan, and B. Recht. Breaking locality accelerates block Gauss-Seidel. In D. Precup and Y. W. Teh, editors, *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pages 3482–3491. PMLR, 06–11 Aug 2017.
- [314] L. G. Valiant. A theory of the learnable. *Communications of the ACM*, 27(11):1134–1142, 1984.
- [315] V. N. Vapnik and A. Y. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. In *Measures of complexity: festschrift for alexey chervonenkis*, pages 11–30. Springer, 2015.
- [316] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [317] L. Venturi, A. S. Bandeira, and J. Bruna. Spurious valleys in one-hidden-layer neural network optimization landscapes. *Journal of Machine Learning Research*, 20:133, 2019.



- [318] R. Vershynin. *High-dimensional probability: An introduction with applications in data science*, volume 47. Cambridge University Press, 2018.
- [319] B. A. Vostrecov and M. A. Kreĭnes. Approximation of continuous functions by superpositions of plane waves. *Dokl. Akad. Nauk SSSR*, 140:1237–1240, 1961.
- [320] S. Wang and X. Sun. Generalization of hinging hyperplanes. *IEEE Transactions on Information Theory*, 51(12):4425–4431, 2005.
- [321] Z. Wang, A. Albarghouthi, G. Prakriya, and S. Jha. Interval universal approximation for neural networks. *Proceedings of the ACM on Programming Languages*, 6(POPL):1–29, 2022.
- [322] E. Weinan, C. Ma, and L. Wu. Barron spaces and the compositional function spaces for neural network models. *arXiv preprint arXiv:1906.08039*, 2019.
- [323] E. Weinan and S. Wojtowytsch. Representation formulas and pointwise properties for barron functions. *Calculus of Variations and Partial Differential Equations*, 61(2):46, 2022.
- [324] S. Weissmann, A. Wilson, and J. Zech. Multilevel optimization for inverse problems. In P.-L. Loh and M. Raginsky, editors, *Proceedings of Thirty Fifth Conference on Learning Theory*, volume 178 of *Proceedings of Machine Learning Research*, pages 5489–5524. PMLR, 02–05 Jul 2022.
- [325] A. C. Wilson, B. Recht, and M. I. Jordan. A lyapunov analysis of accelerated methods in optimization. *Journal of Machine Learning Research*, 22(113):1–34, 2021.
- [326] A. C. Wilson, R. Roelofs, M. Stern, N. Srebro, and B. Recht. The marginal value of adaptive gradient methods in machine learning. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [327] D. R. Wilson and T. R. Martinez. The general inefficiency of batch training for gradient descent learning. *Neural Netw.*, 16(10):1429–1451, Dec. 2003.
- [328] C. Xiao, J.-Y. Zhu, B. Li, W. He, M. Liu, and D. Song. Spatially transformed adversarial examples. *arXiv preprint arXiv:1801.02612*, 2018.
- [329] R. Xiong, Y. Yang, D. He, K. Zheng, S. Zheng, C. Xing, H. Zhang, Y. Lan, L. Wang, and T. Liu. On layer normalization in the transformer architecture. In *International conference on machine learning*, pages 10524–10533. PMLR, 2020.

- [330] H. Xu and S. Mannor. Robustness and generalization. *Machine learning*, 86:391–423, 2012.
- [331] J. Xu, X. Sun, Z. Zhang, G. Zhao, and J. Lin. Understanding and improving layer normalization. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [332] D. Yarotsky. Error bounds for approximations with deep ReLU networks. *Neural Netw.*, 94:103–114, 2017.
- [333] D. Yarotsky. Universal approximations of invariant maps by neural networks. *Constructive Approximation*, 55(1):407–474, 2022.
- [334] D. Yarotsky and A. Zhevnerchuk. The phase diagram of approximation rates for deep neural networks. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 13005–13015. Curran Associates, Inc., 2020.
- [335] C. Yun, S. Bhojanapalli, A. S. Rawat, S. J. Reddi, and S. Kumar. Are transformers universal approximators of sequence-to-sequence functions?, 2019.
- [336] C. Yun, Y.-W. Chang, S. Bhojanapalli, A. S. Rawat, S. Reddi, and S. Kumar.  $O(n)$  connections are expressive enough: Universal approximability of sparse transformers. *Advances in Neural Information Processing Systems*, 33:13783–13794, 2020.
- [337] M. D. Zeiler. Adadelata: An adaptive learning rate method. *CoRR*, abs/1212.5701, 2012.
- [338] X. Zhai, A. Kolesnikov, N. Houlsby, and L. Beyer. Scaling vision transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 12104–12113, 2022.
- [339] C. Zhang, S. Bengio, M. Hardt, B. Recht, and O. Vinyals. Understanding deep learning requires rethinking generalization, 2016.
- [340] D.-X. Zhou. Universality of deep convolutional neural networks. *Applied and computational harmonic analysis*, 48(2):787–794, 2020.

## 术语索引

| 中文术语     | 英文术语                               | 页码  |
|----------|------------------------------------|-----|
| 逼近论      | approximation theory               | vii |
| 优化理论     | optimization theory                | vii |
| 统计学习理论   | statistical learning theory        | vii |
| 深度神经网络   | deep neural network                | 2   |
| 神经元      | neuron                             | 2   |
| 权重向量     | weight vector                      | 2   |
| 偏置       | bias                               | 2   |
| 激活函数     | activation function                | 2   |
| 前馈神经网络   | feedforward neural network         | 3   |
| 浅层前馈神经网络 | shallow feedforward neural network | 3   |
| 仿射变换     | affine transformation              | 3   |
| 深层前馈神经网络 | deep feedforward neural network    | 3   |
| 层数       | number of layers                   | 3   |
| 参数       | parameters                         | 3   |
| 架构       | architecture                       | 3   |
| 目标函数     | objective function                 | 3   |
| 监督学习     | supervised learning                | 3   |
| 训练数据     | training data                      | 3   |
| 样本       | sample                             | 3   |
| 损失函数     | loss function                      | 4   |
| 经验风险     | empirical risk                     | 4   |
| 训练点      | training points                    | 4   |
| 反向传播     | backpropagation                    | 4   |
| 数据分布     | data distribution                  | 4   |
| 风险       | risk                               | 5   |
| 泛化误差     | generalization error               | 5   |
| 过拟合      | overfitting                        | 5   |
| 万能逼近定理   | universal approximation theorem    | 5   |

| 中文术语         | 英文术语                                   | 页码 |
|--------------|----------------------------------------|----|
| 维数灾难         | curse of dimensionality                | 5  |
| 过参数化机制       | overparameterized regime               | 6  |
| 对抗样本         | adversarial example                    | 6  |
| 无监督学习        | unsupervised learning                  | 8  |
| 物理信息神经网络     | physics-informed neural network        | 8  |
| 强化学习         | reinforcement learning                 | 8  |
| 深度           | depth                                  | 10 |
| 宽度           | width                                  | 10 |
| 权重矩阵         | weight matrix                          | 10 |
| 偏置向量         | bias vector                            | 10 |
| 节点           | node                                   | 11 |
| 层            | layer                                  | 11 |
| 输入层          | input layer                            | 11 |
| 输出层          | output layer                           | 11 |
| 隐藏层          | hidden layer                           | 11 |
| 浅层网络         | shallow network                        | 11 |
| 残差神经网络       | residual neural network                | 11 |
| 循环神经网络       | recurrent neural network               | 11 |
| 超参数          | hyperparameter                         | 11 |
| 模型           | model                                  | 12 |
| 权重共享         | weight sharing                         | 13 |
| 稀疏性          | sparsity                               | 13 |
| 规模           | size                                   | 13 |
| Sigmoid 激活函数 | sigmoid activation function            | 13 |
| 梯度消失问题       | vanishing gradient problem             | 14 |
| 梯度消失或爆炸效应    | vanishing or exploding gradient effect | 14 |
| 神经元死亡问题      | dead neuron problem                    | 14 |
| 死亡神经元        | dead neuron                            | 14 |
| SiLU 激活函数    | SiLU activation function               | 14 |
| 参数化 ReLU     | parametric ReLU                        | 14 |

| 中文术语      | 英文术语                                   | 页码 |
|-----------|----------------------------------------|----|
| 紧收敛       | compact convergence                    | 16 |
| 万能逼近族     | universal approximator                 | 16 |
| S 形的      | sigmoidal                              | 19 |
| 卷积        | convolution                            | 20 |
| 一元基数 B 样条 | univariate cardinal B-spline           | 30 |
| 多元 B 样条   | multivariate B-spline                  | 30 |
| 共享输入的并行化  | parallelization with shared inputs     | 40 |
| 共享输入的线性组合 | linear combinations with shared inputs | 41 |
| 连续分段线性的   | continuous, piecewise linear (cpwl)    | 41 |
| 区域或片      | region or piece                        | 41 |
| 三角剖分      | triangulation                          | 46 |
| 镶嵌        | tessellation                           | 46 |
| 单纯形网格     | simplicial mesh                        | 46 |
| 仿射无关      | affinely independent                   | 47 |
| $n$ -单纯形  | $n$ -simplex                           | 47 |
| 正则三角剖分    | regular triangulation                  | 47 |
| 节点        | node                                   | 47 |
| 单元        | element                                | 47 |
| 内部节点      | interior node                          | 48 |
| 节点片       | patch                                  | 48 |
| 局部凸       | locally convex                         | 50 |
| 仿射包       | affine hull                            | 50 |
| Hölder 连续 | Hölder continuous                      | 52 |
| 片 (或线性区域) | pieces (or linear regions)             | 56 |
| 断点        | break point                            | 56 |
| 随机偏置神经网络  | random-bias neural network             | 62 |
| 最大内部导数    | maximal internal derivative            | 62 |
| 解析函数      | analytic function                      | 71 |
| 深度分离      | depth separation                       | 72 |
| 单位分解方法    | partition of unity method              | 74 |

| 中文术语          | 英文术语                                   | 页码  |
|---------------|----------------------------------------|-----|
| 维数灾难          | Curse of Dimensionality (CoD)          | 80  |
| 鼓包函数          | bump function                          | 81  |
| 连续非线性 $N$ -宽度 | continuous nonlinear $N$ -width        | 83  |
| Barron 类      | Barron class                           | 88  |
| 具有复合结构的函数     | functions with compositional structure | 92  |
| 插值            | interpolation                          | 100 |
| Lipschitz 常数  | Lipschitz constant                     | 102 |
| 极小化子          | minimizer                              | 109 |
| 步长            | step size                              | 109 |
| 学习率           | learning rate                          | 109 |
| 梯度下降法         | gradient descent                       | 109 |
| $L$ -光滑的      | $L$ -smooth                            | 110 |
| 凸函数           | convex function                        | 112 |
| $\mu$ -强凸的    | $\mu$ -strongly convex                 | 112 |
| 线性收敛          | linear convergence                     | 113 |
| 条件数           | condition number                       | 113 |
| 小批量           | mini-batch                             | 115 |
| 轮次            | epoch                                  | 115 |
| 塔式性质          | tower property                         | 118 |
| 无岭            | ridgeless                              | 135 |
| 岭正则化          | ridge regularization                   | 135 |
| 训练点           | training point                         | 136 |
| 最小范数解         | minimum norm solution                  | 136 |
| 岭回归           | ridge regression                       | 137 |
| 特征方法          | feature method                         | 139 |
| 特征空间          | feature space                          | 139 |
| 特征映射          | feature map                            | 139 |
| 特征            | feature                                | 139 |
| 表示定理          | representer theorem                    | 140 |
| 核技巧           | kernel trick                           | 140 |

| 中文术语              | 英文术语                                                         | 页码  |
|-------------------|--------------------------------------------------------------|-----|
| 核                 | kernel                                                       | 140 |
| 核矩阵               | kernel matrix                                                | 140 |
| (有岭或无岭) 核最小二乘估计量  | (ridge or ridgeless) kernel least-squares estimator          | 141 |
| 在初始化处关于参数线性化模型    | linearizing the model in the parameter around initialization | 143 |
| 经验切线核             | empirical tangent kernel                                     | 143 |
| LeCun 初始化         | LeCun initialization                                         | 152 |
| 神经切线核             | neural tangent kernel                                        | 153 |
| NNGP 核            | NNGP kernel                                                  | 154 |
| 均值函数              | mean function                                                | 160 |
| 协方差函数             | covariance function                                          | 160 |
| Gaussian 过程       | Gaussian process                                             | 161 |
| 反向动力学             | backward dynamics                                            | 164 |
| 前向动力学             | forward dynamics                                             | 164 |
| 归一化初始化            | normalized initialization                                    | 164 |
| NTK 初始化           | NTK initialization                                           | 164 |
| 损失景观              | loss landscape                                               | 167 |
| 实现映射              | realization map                                              | 167 |
| 伪谷                | spurious valley                                              | 169 |
| 中心                | center                                                       | 179 |
| 星形的               | star-shaped                                                  | 179 |
| $\varepsilon$ -凸的 | epsilon-convex                                               | 181 |
| 最佳逼近性质            | best approximation property                                  | 183 |
| 唯一最佳逼近性质          | unique best approximation property                           | 183 |
| 连续选取性质            | continuous selection property                                | 183 |
| 特征空间              | feature space                                                | 188 |
| 标签空间              | label space                                                  | 188 |
| (总体) 风险           | (population) risk                                            | 189 |
| Bayes 风险          | Bayes risk                                                   | 189 |
| 二元交叉熵损失           | binary cross-entropy loss                                    | 189 |



| 中文术语               | 英文术语                               | 页码  |
|--------------------|------------------------------------|-----|
| 假设集                | hypothesis set                     | 190 |
| 经验风险极小化子           | empirical risk minimizer           | 190 |
| 逼近误差               | approximation error                | 191 |
| 插值误差               | interpolation error                | 191 |
| 泛化界                | generalization bound               | 191 |
| $\varepsilon$ -覆盖数 | $\varepsilon$ -covering number     | 193 |
| 稀疏连接网络             | sparsely connected networks        | 195 |
| 逼近-复杂度权衡           | approximation-complexity trade-off | 198 |
| 打散                 | shattered                          | 200 |
| VC 维               | VC dimension                       | 201 |
| 试探函数               | ansatz function                    | 209 |
| Transformer        | transformer                        | 244 |