

现代机器学习中的概率

ORF 526 课程材料译稿

第 1–2 讲：高斯分布（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 高斯分布及其线性结构

第 1、2 讲：高斯分布
定义、线性结构，以及作为投影的条件化。

纲要： $\varphi_X = \exp(\text{二次式}) \longrightarrow AX+b$ 为高斯随机向量 $\longrightarrow$ 不相关 $\Rightarrow$ 独立 $\longrightarrow$ 条件化是正交投影 $\longrightarrow$ 岭回归与去噪。
阅读指南： 带星号的节不在课堂讲授。这些节的内容完整，也属于考试范围，其中包含了大多数习题。习题分为 A 类（是否跟上讲课）、B 类（是否理解论证）和 C 类（需要一个思路；找到思路后就很短）。每周小测三类各出一题。

1.1 傅里叶分析中的几个事实

以下两个事实是标准结果，我们不予证明。傅里叶变换使用 $e^{-ix\cdot\xi}$，逆变换使用 $e^{+ix\cdot\xi}$。

命题 1.1 (傅里叶分析，引入的结果)**.** 对 $f \in L^1(\mathbb{R}^d)$，定义

$$\widehat{f}(\xi) = \int_{\mathbb{R}^d} f(x) e^{-ix\cdot\xi}\, dx, \qquad \xi \in \mathbb{R}^d.$$

则：

(i) **反演**。若 $f, \widehat{f} \in L^1(\mathbb{R}^d)$，则在 f 的每一个连续点处，

$$f(x) = (2\pi)^{-d} \int_{\mathbb{R}^d} \widehat{f}(\xi) e^{ix\cdot\xi}\, d\xi.$$

(ii) **导数**。若 $f, \partial_j f \in L^1$，则 $\widehat{\partial_j f}(\xi) = i\xi_j \widehat{f}(\xi)$；若 $x_j f \in L^1$，则 $\partial_{\xi_j} \widehat{f}(\xi) = \widehat{(-ix_j f)}(\xi)$。对 x 求导对应乘以 $i\xi_j$，乘以 x_j 对应 $i\partial_{\xi_j}$。

(iii) **等距性**。对 $f \in L^1 \cap L^2$，有 $\|\widehat{f}\|_{L^2}^2 = (2\pi)^d \|f\|_{L^2}^2$，且该变换可延拓为 $L^2(\mathbb{R}^d)$ 到自身的双射。

(iv) **唯一性**。设 W, W' 是 $\mathbb{R}^d$ 中的随机向量。若对每个 ξ 都有 $\mathbb{E}[e^{-iW\cdot\xi}] = \mathbb{E}[e^{-iW'\cdot\xi}]$，则 $W \overset{d}{=} W'$。若 h 满足 $\mathbb{E}|h(W)| < \infty$，且对每个 ξ 都有 $\mathbb{E}[h(W)e^{-iW\cdot\xi}] = 0$，则 $h(W) = 0$。

引入的结果：极限与期望的交换

设 Z, Z_n, Z_t 为随机变量。

(a) **控制收敛**。若 $Z_n \to Z$ 且 $|Z_n| \le W$，其中 $\mathbb{E}W < \infty$，则 $\mathbb{E}Z_n \to \mathbb{E}Z$。将 $\mathbb{E}$ 换成积分 $\int \cdot\, dx$，同样成立。

(b) **Fatou 引理**。若 $Z_n \ge 0$ 且 $Z_n \to Z$，则 $\mathbb{E}Z \le \liminf_n \mathbb{E}Z_n$。

(c) **求导**。若 $\lambda \mapsto Z_\lambda$ 的差商被同一个可积随机变量控制，则 $\frac{d}{d\lambda}\mathbb{E}[Z_\lambda] = \mathbb{E}[\partial_\lambda Z_\lambda]$。

(d) **Fubini 定理**。若 $\mathbb{E}\int |Z_t|\, dt < \infty$，则 $\mathbb{E}\int Z_t\, dt = \int \mathbb{E}[Z_t]\, dt$。

1.2 定义

定义 1.2 (特征函数). $\mathbb{R}^d$ 中随机向量 X 的特征函数为

$$\varphi_X(\xi) = \mathbb{E}[e^{-iX\cdot\xi}], \qquad \xi \in \mathbb{R}^d.$$

它对每个 X 都有定义，无须任何可积性假设，因为 $|e^{i\theta}| = 1$。直接可得 $\varphi_X(0) = 1$、$|\varphi_X(\xi)| \le 1$ 和 $\varphi_X(-\xi) = \overline{\varphi_X(\xi)}$。

定义 1.3 (高斯随机向量). 设 $\mu \in \mathbb{R}^d$，Σ 是对称的 $d \times d$ 矩阵。若 $\mathbb{R}^d$ 中的随机向量 X 满足

$$\varphi_X(\xi) = \exp\left(-i\mu\cdot\xi - \tfrac{1}{2}\xi^\top\Sigma\xi\right) \qquad \text{对每个}\xi \in \mathbb{R}^d,$$

则称 X 是均值为 μ、协方差为 Σ 的高斯随机向量，记作 $X \sim \mathcal{N}(\mu, \Sigma)$。

由命题 1.1(iv)，满足此条件的分布至多有一个；何时存在这样的分布将在下一节解决。

命题 1.4 (参数名副其实). 若 $X \sim \mathcal{N}(\mu, \Sigma)$，则 $\mathbb{E}|X|^2 < \infty$，且

$$\mathbb{E}[X_j] = \mu_j, \qquad \mathbb{E}[(X_j - \mu_j)(X_k - \mu_k)] = \Sigma_{jk}.$$

特别地，分布决定 (μ, Σ)，因此两个高斯随机向量同分布当且仅当它们的参数相同。

证明. 令 $\psi(\xi) = -i\mu\cdot\xi - \frac{1}{2}\xi^\top\Sigma\xi$，则 $\varphi_X = e^\psi$ 光滑，且

$$\begin{aligned}\partial_j\varphi_X|_{\xi=0} &= -i\mu_j,\\ \partial_j\partial_k\varphi_X|_{\xi=0} &= (\partial_j\partial_k\psi + \partial_j\psi\,\partial_k\psi)|_{\xi=0} = -\Sigma_{jk} - \mu_j\mu_k.\end{aligned}$$

二阶矩有限并非假设，而是由这种光滑性所迫。对 $h > 0$，

$$\frac{2\varphi_X(0) - \varphi_X(he_j) - \varphi_X(-he_j)}{h^2} = \mathbb{E}\left[\frac{2 - 2\cos(hX_j)}{h^2}\right],$$

当 $h \downarrow 0$ 时，左边收敛到 $-\partial_j^2\varphi_X(0) = \Sigma_{jj} + \mu_j^2$。被积函数非负并逐点收敛到 X_j^2，因此 Fatou 引理给出 $\mathbb{E}[X_j^2] \le \Sigma_{jj} + \mu_j^2 < \infty$。

有了 $\mathbb{E}|X|^2 < \infty$，$e^{-iX\cdot\xi}$ 的差商分别被 $|X_j|$ 和 $|X_jX_k|$ 控制，所以可在期望内求两次导数：$\partial_j\varphi_X(0) = -i\mathbb{E}[X_j]$，$\partial_j\partial_k\varphi_X(0) = -\mathbb{E}[X_jX_k]$。与上式比较即得 $\mathbb{E}[X_j] = \mu_j$ 和 $\mathbb{E}[X_jX_k] = \Sigma_{jk} + \mu_j\mu_k$。 □

定理 1.5 (仿射像). 若 $X \sim \mathcal{N}(\mu, \Sigma)$，$A \in \mathbb{R}^{m\times d}$ 且 $b \in \mathbb{R}^m$，则 $AX + b \sim \mathcal{N}(A\mu + b, A\Sigma A^\top)$。

证明. $\varphi_{AX+b}(\xi) = e^{-ib\cdot\xi}\mathbb{E}[e^{-iX\cdot(A^\top\xi)}] = e^{-ib\cdot\xi}\varphi_X(A^\top\xi)$。代入定义 1.3 并利用 $\mu\cdot A^\top\xi = (A\mu)\cdot\xi$，得到 $\exp(-i(A\mu+b)\cdot\xi - \frac{1}{2}\xi^\top A\Sigma A^\top\xi)$。 □

推论 1.6 (旋转不变性). 若 $X \sim \mathcal{N}(0, I_d)$ 且 $O \in O(d)$，则 $OX \overset{d}{=} X$。更一般地，对 $X \sim \mathcal{N}(0, \Sigma)$，恰当且仅当 $O\Sigma O^\top = \Sigma$ 时，$OX \overset{d}{=} X$。

证明. 定理 1.5 给出 $OX \sim \mathcal{N}(0, O\Sigma O^\top)$；由命题 1.4，这一分布等于 $\mathcal{N}(0, \Sigma)$ 当且仅当 $O\Sigma O^\top = \Sigma$。当 $\Sigma = I_d$ 时，这就是 $OO^\top = I_d$。 □

习题 1.9 表明，在坐标独立的分布中，此性质刻画了高斯分布。

推论 1.7 (逐个坐标)**.** $X \sim \mathcal{N}(\mu, \Sigma)$ 当且仅当对每个 $v \in \mathbb{R}^d$，都有 $v \cdot X \sim \mathcal{N}(v \cdot \mu, v^\top \Sigma v)$。

证明. 正向：在定理 1.5 中取 $A = v^\top$。反向：标量 $v \cdot X$ 的特征函数在 1 处的值为 $\mathbb{E}[e^{-iv \cdot X}] = \varphi_X(v)$；由假设，它等于 $\exp(-iv \cdot \mu - \frac{1}{2} v^\top \Sigma v)$，这就是定义 1.3。 □

习题 1.8 (A 类)**.** 设 $\mathbb{R}^2$ 上 $X \sim \mathcal{N}(\mu, \Sigma)$，其中 $\mu = (1, -1)$，$\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$。

(a) 显式写出 $\varphi_X(\xi)$，并按命题 1.4 中的方法通过求导求回 $\mathbb{E}[X_1 X_2]$。

(b) 用定理 1.5 求 $X_1 + X_2$、$X_1 - X_2$ 以及二元组 $(X_1 + X_2, X_1 - X_2)$ 的分布。前两个量是否独立？

(c) 现在令 Σ 为 $\mathbb{R}^2$ 上任意协方差矩阵。对哪些 Σ，$X_1 + X_2$ 与 $X_1 - X_2$ 独立？对哪些 Σ，存在 $v \neq 0$ 使 $v \cdot X$ 为常数？

习题 1.9 (C 类)**.** 设 $d \geq 2$，X 的坐标独立同分布，且对每个 $O \in O(d)$ 都有 $OX \overset{d}{=} X$。证明对某个 $c \geq 0$，$X \sim \mathcal{N}(0, cI_d)$。可以使用特征函数连续这一事实。

1.3 存在性

到目前为止，我们还没有展示出任何一个高斯随机向量。

引理 1.10. 设 g 在 $\mathbb{R}$ 上的密度为 $(2\pi)^{-1/2} e^{-x^2/2}$。则 $\mathbb{E}[e^{-i\lambda g}] = e^{-\lambda^2/2}$，即 $g \sim \mathcal{N}(0, 1)$。

证明. 令 $f(\lambda) = \mathbb{E}[e^{-i\lambda g}]$。$\lambda \mapsto e^{-i\lambda g}$ 的差商被 $|g|$ 控制，因此可以在期望内求导：

$$f'(\lambda) = \frac{-i}{\sqrt{2\pi}} \int_{\mathbb{R}} x e^{-i\lambda x} e^{-x^2/2} \, dx.$$

关键观察是 $x e^{-x^2/2} = -\frac{d}{dx} e^{-x^2/2}$；它将因子 x 变为导数，再通过分部积分移到另一因子上：

$$\begin{aligned} f'(\lambda) &= \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-i\lambda x} \frac{d}{dx}\left(e^{-x^2/2}\right) dx \\ &= \frac{-i}{\sqrt{2\pi}} \int_{\mathbb{R}} \left(\frac{d}{dx} e^{-i\lambda x}\right) e^{-x^2/2} \, dx = -\lambda f(\lambda). \end{aligned}$$

结合 $f(0) = 1$，这迫使 $f(\lambda) = e^{-\lambda^2/2}$。 □

注 1.11. 证明中使用了 $\mathbb{E}[g\, h(g)] = \mathbb{E}[h'(g)]$，其中 $h(x) = e^{-i\lambda x}$：对标准高斯而言，乘以 g 的作用类似于求导。这一事实将在第 4、5 讲再次出现。

若 $Z = (g_1, \ldots, g_d)$ 的各坐标为独立标准正态变量，则

$$\varphi_Z(\xi) = \prod_{j=1}^{d} \mathbb{E}[e^{-i\xi_j g_j}] = \prod_{j=1}^{d} e^{-\xi_j^2/2} = e^{-|\xi|^2/2},$$

所以 $Z \sim \mathcal{N}(0, I_d)$。

命题 1.12 (适定性)**.** 设 $\mu \in \mathbb{R}^d$，Σ 对称。存在满足定义 1.3 的随机向量，当且仅当 $\Sigma \succeq 0$；此时其分布唯一。若 $\Sigma = AA^\top$，可取 $X = AZ + \mu$，其中 $Z \sim \mathcal{N}(0, I_d)$。

证明. 若 $\Sigma \succeq 0$,将其分解为 $\Sigma = AA^\top$。对 $Z \sim \mathcal{N}(0, I_d)$ 应用定理 1.5,得 $AZ+\mu \sim \mathcal{N}(\mu, AA^\top) = \mathcal{N}(\mu, \Sigma)$。分布的唯一性来自命题 1.1(iv)。

反之，假设 $v^\top \Sigma v = -c$，其中 $c > 0$。沿 $\xi = sv$，定义 1.3 右侧的模为 $e^{s^2 c/2} \to \infty$，与 $|\varphi_X| \le 1$ 矛盾。 □

因此，$\mathbb{R}^d$ 上的高斯分布恰好由 $\mathbb{R}^d \times \mathrm{Sym}_{\ge 0}(\mathbb{R}^d)$ 编号。

例 1.13 (退化情形)**.** 取 $d = 2$、$\mu = 0$、$\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$；它是秩为 1 的半正定矩阵。由命题 1.12，分布 $\mathcal{N}(0, \Sigma)$ 存在，取 $A = \binom{1}{1}$ 可将其实现为 $X = (g, g)$。该分布支撑在一条直线上，因此没有密度，而定义 1.3 完全不受影响；若通过密度 $\propto e^{-\frac{1}{2}x^\top \Sigma^{-1} x}$ 定义，就会排除这种情形。

习题 1.14 (A 类)**.** 令 $\mathbb{R}^d$ 上 $f(x) = (2\pi)^{-d/2} e^{-|x|^2/2}$。证明 $\widehat{f}(\xi) = e^{-|\xi|^2/2}$，然后计算

$$(2\pi)^{-d} \int_{\mathbb{R}^d} e^{-|\xi|^2/2} e^{ix\cdot\xi}\, d\xi$$

并求回 f，以验证命题 1.1(i) 对这一对函数成立。由此说明标准高斯密度在相差因子 $(2\pi)^{d/2}$ 的意义下是傅里叶变换的不动点。

习题 1.15 (B 类)**.** 设 $\Sigma \succ 0$，写成 $\Sigma = AA^\top$，其中 A 可逆，令 $X = AZ + \mu$。

(a) 对 Z 的密度作变量替换，得到 $p_X(x) = (2\pi)^{-d/2} (\det \Sigma)^{-1/2} \exp[-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)]$，并检验结果与所选平方根 A 无关。

(b) 证明当 Σ 奇异时不存在密度：构造 $v \neq 0$ 使 $v \cdot (X - \mu) = 0$，并由此说明 X 落在一个维数小于 d 的仿射子空间上。

1.4 不相关与独立

定理 1.16. 设 (X, Y) 在 $\mathbb{R}^d \times \mathbb{R}^{d'}$ 中联合高斯，即拼接后的向量为高斯向量，且 $\mathrm{Cov}(X, Y) = 0$。则 $X \perp\!\!\!\perp Y$。

证明. 写 $\xi = (s, u)$。拼接向量的协方差为块对角矩阵，所以 $\xi^\top \Sigma \xi = s^\top \Sigma_{XX} s + u^\top \Sigma_{YY} u$，$\mu \cdot \xi = \mu_X \cdot s + \mu_Y \cdot u$。因此

$$\varphi_{(X,Y)}(s, u) = \varphi_X(s) \varphi_Y(u),$$

这正是由相互独立且分别满足 $X' \overset{d}{=} X$、$Y' \overset{d}{=} Y$ 的随机向量构成的二元组 (X', Y') 的特征函数。由命题 1.1(iv)，$(X, Y) \overset{d}{=} (X', Y')$，故 $X \perp\!\!\!\perp Y$。 □

在实际中失效的假设是联合高斯性，而不是边缘分布的高斯性。

例 1.17 (不相关、标准正态但不独立)**.** 设 $g \sim \mathcal{N}(0,1)$，ε 是独立的随机符号；令 $X = g$、$Y = \varepsilon g$。给定 $\varepsilon = \pm 1$ 时，$Y = \pm g \overset{d}{=} g$，故两个边缘分布均为标准正态。它们不相关，因为 $\mathbb{E}[XY] = \mathbb{E}[\varepsilon]\mathbb{E}[g^2] = 0$。而 $|X| = |Y|$ 恒成立，所以 X 决定 Y，只差一个符号。

对 ε 条件化并应用引理 1.10，

$$\varphi_{(X,Y)}(s,u) = \tfrac{1}{2}e^{-(s+u)^2/2} + \tfrac{1}{2}e^{-(s-u)^2/2},$$

这是两个高斯变换之和，而非 exp(二次式)。尽管每个坐标都满足定义 1.3，二元组却不满足。

习题 1.18 (B 类)**.** 继续例 1.17。

(a) 求 $X+Y$ 的分布，并通过找出一个原子说明它不是高斯分布。

(b) 推论 1.7 说，只要向量的每个线性泛函都是高斯的，该向量就是高斯向量。对任意 s,u 计算 $sX+uY$ 的分布，并说明为何没有矛盾。

(c) (X,Y) 在 $\mathbb{R}^2$ 上有密度吗?

1.5 * 熵，以及高斯分布为何使熵最大

本节不在课堂讲授。习题须在第 2 讲开始时交。

在 $\mathbb{R}^d$ 上所有具有给定均值和协方差 $\Sigma \succ 0$ 的分布中，高斯分布的微分熵最大。本节证明这一点；第 3 讲将用到这一结论。

若一个概率为 p 的事件发生，其惊异度 $s(p)$ 应满足 $s(1) = 0$ 和 $s(pq) = s(p) + s(q)$。代入 $p = e^{-u}$，后一个条件变为 $g(u+v) = g(u) + g(v)$，其中 $g(u) = s(e^{-u})$；它的连续解只有线性函数。因此 $s(p) = -c\log p$，对数的底决定单位，我们取 $c = 1$。

有限集上分布的熵是在观察之前的期望惊异度，

$$H(p) = \mathbb{E}[-\log p(X)] = -\sum_x p(x)\log p(x),$$

对于 $\mathbb{R}^d$ 上的密度 p，同一公式定义微分熵 $h(p) = -\int p\log p$。后者不是前者的另一种写法。

习题 1.19 (A 类)**.** (a) 计算正面概率为 q 的硬币的 H；画出其在 $q \in [0,1]$ 上的图像并求最大值所在。计算 n 个点上均匀分布的 H。

(b) 计算 $[0,a]$ 上均匀分布、速率为 λ 的指数分布及 $\mathcal{N}(0,\sigma^2)$ 的 h；最后一个应得到

$$\tfrac{1}{2}\log(2\pi e\sigma^2).$$

给出微分熵为负的分布，并说明离散熵为何不可能为负。

(c) 证明 $h(aX) = h(X) + \log|a|$，其中 $a \neq 0$。因此“长度的熵”并非一个定义良好的数，而 H 完全没有单位。

第 (c) 问表明 h 并不是表述最大化问题的合适量，于是相对于参考分布度量熵：对密度 p, q，相对熵为 $D(p\|q) = \int p\log(p/q)$。

习题 1.20 (B 类)**.** 证明 Gibbs 不等式：$D(p\|q)\ge 0$，等号成立当且仅当 $p=q$。对 $-\log$ 使用 Jensen 不等式。取 q 为均匀分布，推得其离散形式：n 个点上的任意分布都满足 $H(p)\le \log n$，等号仅对均匀分布成立。然后检验，当 X 被重新缩放时，$D(p\|q)$ 不变；h 则不同。

现在固定 μ 和 $\Sigma\succ 0$，令 q 为高斯密度，p 为具有该均值和协方差的任意密度。展开 $0\le D(p\|q)$ 得到 $0\le -h(p)-\int p\log q$；关键在第二项。

习题 1.21 (B 类)**.** 写出 $\log q$ 并观察它是 x 的二次多项式。由此推得 $\int p\log q$ 只通过均值和协方差依赖于 p，故等于 $\int q\log q=-h(q)$。证明 $h(p)\le h(q)$，等号仅在 $p=q$ 时成立，并检验 $h(q)=\frac12\log[(2\pi e)^d\det\Sigma]$。

这个论证只用到 $\log q$ 是二次式，因此 $\int p\log q$ 只通过前两阶矩了解 p。

习题 1.22 (C 类)**. 译注：**以下熵的加减及次可加性论证须在所涉微分熵有限或已明确良定义的条件下使用，不能对未定义的熵或 $\infty-\infty$ 作代数运算。仅有密度并不自动满足这一要求。

设 X,Y 独立同分布、对称且各有密度。证明

$$h\left(\frac{X+Y}{\sqrt2}\right)\ge h(X).$$

可以使用次可加性 $h(U,V)\le h(U)+h(V)$；这是对联合密度和其边缘密度之积应用 Gibbs 不等式所得。

习题 1.23 (C 类)**.** 固定 $S\subseteq\mathbb{R}^d$、S 上的函数 $T_1,\dots,T_k$ 和数 $c_1,\dots,c_k$。假设存在 $\lambda_1,\dots,\lambda_k$，使 $\exp(\sum_m\lambda_mT_m)$ 在 S 上的积分 Z 有限，因此 $q=Z^{-1}\exp(\sum_m\lambda_mT_m)$ 是一个密度，并且对每个 m 有 $\int qT_m=c_m$。证明在 S 上具有这些矩的密度中，q 唯一地使 h 最大。

将 $[0,a]$ 上的均匀分布、$[0,\infty)$ 上给定均值的指数分布和给定均值及协方差的 $\mathcal{N}(\mu,\Sigma)$ 作为特例求出。最后说明该假设确有作用：当 $S=\mathbb{R}$ 而只约束均值时，没有 λ 使 $e^{\lambda x}$ 可积，而且不存在最大化者——构造均值为 0 而 h 任意大的密度。

2 作为投影的条件化

问题：我们观测到 Y。对 X 的最佳猜测是什么？

2.1 期望是投影

设 $Z\sim\nu$ 是 $\mathbb{R}^k$ 中的随机向量，$f:\mathbb{R}^k\to\mathbb{R}$ 满足 $\mathbb{E}[f(Z)^2]<\infty$。

引理 2.1. $\mathbb{E}[f(Z)]=\arg\min_{c\in\mathbb{R}}\mathbb{E}[(f(Z)-c)^2]$，且最小值为 $\mathrm{Var}(f(Z))$。

证明. $\mathbb{E}[(f(Z)-c)^2]=\mathbb{E}[(f(Z)-\mathbb{E}f(Z))^2]+(\mathbb{E}f(Z)-c)^2$，因为交叉项为 $2(\mathbb{E}f(Z)-c)\mathbb{E}[f(Z)-\mathbb{E}f(Z)]=0$。 □

两种理解。第一，$\mathbb{E}[f(Z)]$ 是对 $f(Z)$ 的最佳确定性猜测。第二，写

$$L^2(\nu)=\{f:\mathbb{R}^k\to\mathbb{R}\mid\mathbb{E}[f(Z)^2]<\infty\},\qquad\langle f,g\rangle_\nu=\mathbb{E}[f(Z)g(Z)].$$

只要将满足 $\mathbb{E}[(f(Z)-g(Z))^2]=0$ 的 f,g 视为同一元素，这就是内积；下文均作此约定。我们使用 L^2 的标准性质：它是完备的，且每个闭子空间 H 都有唯一正交投影 Π_H，其特征为 $\Pi_H f\in H$ 且 $f-\Pi_H f\perp H$，并且它是 H 上 $\|f-h\|_\nu$ 的唯一极小元。

由于 $\mathbb{E}[(f(Z)-c)^2]=\|f-c\|_\nu^2$，引理 2.1 表明，当 H 为常数构成的空间时，$\mathbb{E}[f(Z)]=\Pi_H f$。

2.2 条件期望

设 $Z=(X,Y)$，其中 $X\in\mathbb{R}$、$Y\in\mathbb{R}^m$，记 Y 的分布为 ν_Y。由于 $\mathbb{E}[g(Y)^2]$ 在 ν 和 ν_Y 下计算得到相同的数，映射 $g\mapsto((x,y)\mapsto g(y))$ 将 $L^2(\nu_Y)$ 等同于 $L^2(\nu)$ 的一个闭子空间：只依赖于 Y 的函数空间。

定义 2.2 (条件期望)**.** $\mathbb{E}[X\mid Y]$ 是 X 到 $L^2(\nu_Y)$ 的正交投影。

按构造，它是 $L^2(\nu_Y)$ 的一个元素，即 Y 的函数。

引理 2.3. 对 $m\in L^2(\nu_Y)$，下列条件等价：

(i) $m=\mathbb{E}[X\mid Y]$；

(ii) 对每个 $g\in L^2(\nu_Y)$，$\mathbb{E}[(X-m(Y))g(Y)]=0$；

(iii) m 在 $g\in L^2(\nu_Y)$ 中使 $\mathbb{E}[(X-g(Y))^2]$ 最小。

此外，对每个 $g\in L^2(\nu_Y)$，

$$\mathbb{E}[(X-g(Y))^2]=\mathbb{E}[(X-\mathbb{E}[X\mid Y])^2]+\mathbb{E}[(\mathbb{E}[X\mid Y]-g(Y))^2]. \tag{1}$$

证明. 等价性来自 Π_H 的刻画；恒等式即勾股定理。 □

对 $X\in\mathbb{R}^p$，将该定义逐坐标应用。

2.3 塔式性质

命题 2.4. 设 $Z=(X,Y,V)$，则

$$\mathbb{E}[\mathbb{E}[X\mid Y,V]\mid Y]=\mathbb{E}[X\mid Y],\qquad\qquad \mathbb{E}[\mathbb{E}[X\mid Y]]=\mathbb{E}[X],$$

并且对有界的 g，$\mathbb{E}[g(Y)X\mid Y]=g(Y)\mathbb{E}[X\mid Y]$。

证明. $L^2(\nu_Y)\subseteq L^2(\nu_{(Y,V)})$，两者均为 $L^2(\nu)$ 的闭子空间。对嵌套的闭子空间 $H_1\subseteq H_2$，向量 $\Pi_{H_2}f-f$ 与 H_2 正交，从而与 H_1 正交，故 $\Pi_{H_1}\Pi_{H_2}f=\Pi_{H_1}f$。第一个恒等式对应上述一对子空间；第二个取 H_1 为 $H_2=L^2(\nu_Y)$ 中的常数空间。第三个等式由对每个 h 都有 $\mathbb{E}[(g(Y)X-g(Y)\mathbb{E}[X\mid Y])h(Y)]=\mathbb{E}[(X-\mathbb{E}[X\mid Y])(gh)(Y)]=0$ 得出。 □

推论 2.5 (全方差公式)**.** 记 $\operatorname{Var}(X\mid Y):=\mathbb{E}[(X-\mathbb{E}[X\mid Y])^2\mid Y]$，则

$$\operatorname{Var}(X)=\mathbb{E}[\operatorname{Var}(X\mid Y)]+\operatorname{Var}(\mathbb{E}[X\mid Y]).$$

译注： 本推论对一般 $X \in L^2$ 的残差平方仅保证属于 L^1，未必属于 L^2。平方的条件期望在此须用可积随机变量的 L^1 延拓，而非只用前文的正交投影定义；全方差恒等式仍成立。

证明. 在式 (1) 中取 $g \equiv \mathbb{E}X$，并对第一项使用 $\mathbb{E}[\mathbb{E}[\cdot \mid Y]] = \mathbb{E}[\cdot]$。 □

习题 2.6 (A 类)**.** 证明 $\operatorname{Var}(\mathbb{E}[X \mid Y]) \le \operatorname{Var}(X)$。刻画等号成立的情形，以及推论 2.5 中第一项承担全部方差的情形。

习题 2.7 (B 类)**.** 设 J 是一枚公平硬币，给定 J 时，X 相应服从 $\mathcal{N}(\pm 1, \sigma^2)$。取 $Y = J$，计算推论 2.5 的两项并与 $\operatorname{Var}(X)$ 核对。接着令 W 是 $X_1, \dots, X_n$ 的函数，且假设 $\mathbb{E}[U \mid X_1, \dots, X_n] = -W/n$。推得 $\mathbb{E}[U \mid W] = -W/n$，并指出所用性质。

2.4 高斯条件化

设 $(X, Y) \sim \mathcal{N}(0, \Sigma)$ 取值于 $\mathbb{R}^p \times \mathbb{R}^m$，协方差分块为 Σ_{XX}、$\Sigma_{XY} = \mathbb{E}[XY^\top]$、$\Sigma_{YY} = \mathbb{E}[YY^\top]$。

引理 2.8. 存在 $A \in \mathbb{R}^{p \times m}$ 使 $A\Sigma_{YY} = \Sigma_{XY}$；任意两个解满足 $A_1 Y = A_2 Y$；若 $\Sigma_{YY} \succ 0$，则解唯一且等于 $\Sigma_{XY}\Sigma_{YY}^{-1}$。

证明. 将方程转置，得到 $\Sigma_{YY}A^\top = \Sigma_{YX}$，它可解当且仅当 Σ_{YX} 的每一列 $\mathbb{E}[YX_i]$ 都属于 $\operatorname{range}\Sigma_{YY} = (\ker \Sigma_{YY})^\perp$。若 $v \in \ker \Sigma_{YY}$，则 $\operatorname{Var}(v \cdot Y) = v^\top \Sigma_{YY} v = 0$，故 $v \cdot Y = 0$，且 $v^\top \mathbb{E}[YX_i] = \mathbb{E}[(v \cdot Y)X_i] = 0$。若 $B = A_1 - A_2$，则 $\operatorname{Cov}(BY) = B\Sigma_{YY}B^\top = 0$，故 $BY = 0$。 □

定理 2.9. 令 A 如引理 2.8 所述，则向量 $X - AY$ 与 Y 独立，且 $\mathbb{E}[X \mid Y] = AY$。

证明. 引理 2.3(ii) 要求找到一个 Y 的函数，其残差与每个 $g(Y)$ 都不相关；残差与 Y 独立即可立即满足这一点。尝试 AY。$(X - AY, Y)$ 是 (X, Y) 的线性像，由定理 1.5 联合高斯，且

$$\operatorname{Cov}(X - AY, Y) = \Sigma_{XY} - A\Sigma_{YY} = 0,$$

故由定理 1.16，$X - AY \perp\!\!\!\perp Y$。于是对每个 $g \in L^2(\nu_Y)$，

$$\mathbb{E}[(X - AY)g(Y)] = \mathbb{E}[X - AY]\mathbb{E}[g(Y)] = 0.$$

□

定理 2.10. 令 $\Sigma_{X|Y} = \Sigma_{XX} - A\Sigma_{YX}$。则对每个 $\xi \in \mathbb{R}^p$，

$$\mathbb{E}[e^{-i\xi \cdot X} \mid Y] = \exp\left(-i\xi \cdot AY - \tfrac{1}{2}\xi^\top \Sigma_{X|Y}\xi\right),$$

即 $X \mid Y \sim \mathcal{N}(AY, \Sigma_{X|Y})$。特别地，$\operatorname{Cov}(X \mid Y) = \Sigma_{X|Y}$ 不依赖于 Y。

证明. 令 $R = X - AY$，它是高斯向量。利用 $A\Sigma_{YY} = \Sigma_{XY}$ 两次，

$$\operatorname{Cov}(R) = \Sigma_{XX} - A\Sigma_{YX} - \Sigma_{XY}A^\top + A\Sigma_{YY}A^\top = \Sigma_{X|Y},$$

故 $\mathbb{E}[e^{-i\xi \cdot R}] = e^{-\frac{1}{2}\xi^\top \Sigma_{X|Y}\xi}$。由定理 2.9，$R \perp\!\!\!\perp Y$，所以这个常数满足引理 2.3(ii) 对 $\mathbb{E}[e^{-i\xi \cdot R} \mid Y]$ 的刻画。写 $e^{-i\xi \cdot X} = e^{-i\xi \cdot AY} e^{-i\xi \cdot R}$，再由命题 2.4 将有界因子提出。 □

当 $\Sigma_{YY} \succ 0$ 时，

$$AY = \Sigma_{XY}\Sigma_{YY}^{-1}Y, \qquad \Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX},$$

后者是 Σ 中 Σ_{YY} 的 Schur 补。对非中心化的 (X, Y)，将 AY 替换为 $\mu_X + A(Y - \mu_Y)$。

2.5 贝叶斯线性模型与岭回归

译注： 本段高斯密度、噪声倒数及得分字典使用非退化噪声 $\sigma \neq 0$，通常取 $\sigma > 0$；$\lambda = \sigma^2/\tau^2$ 还要求 $\tau \neq 0$。所列 $\tau \to 0, \infty$ 是从正参数出发的极限，涉及无正则化逆矩阵时仍须满足相应秩条件。零噪声或零先验不能直接代入含除法的密度公式。

取

$$y = Hw + \sigma\varepsilon, \qquad w \sim \mathcal{N}(0, \tau^2 I_p), \qquad \varepsilon \sim \mathcal{N}(0, I_n) \text{ 且与} w \text{ 独立}.$$

(w, y) 是 (w, ε) 的线性像，故由定理 1.5 联合高斯，并有

$$\Sigma_{ww} = \tau^2 I, \qquad \Sigma_{wy} = \tau^2 H^\top, \qquad \Sigma_{yy} = \tau^2 HH^\top + \sigma^2 I.$$

定理 2.10 给出后验分布；用 $\tau^2 H^\top(\tau^2 HH^\top + \sigma^2 I)^{-1} = (H^\top H + \lambda I)^{-1} H^\top$ 化简：

命题 2.11. 令 $\lambda = \sigma^2/\tau^2$，则

$$\mathbb{E}[w \mid y] = (H^\top H + \lambda I)^{-1} H^\top y, \qquad \operatorname{Cov}(w \mid y) = \sigma^2 (H^\top H + \lambda I)^{-1}.$$

后验均值就是岭回归，其正则化参数为噪声方差与先验方差之比。以下习题须在第 3 讲开始时交。

习题 2.12 (A 类)**.** (a) 证明 $-\log p(y \mid w) = \frac{1}{2\sigma^2}\|y - Hw\|^2 + c$，其中 c 与 w 无关，因此最小二乘是最大似然。说明选择平方误差对噪声作了什么假设。

(b) 证明后验密度的最大化者为 $\widehat{w}_\lambda = \arg\min_w \{\|y - Hw\|^2 + \lambda\|w\|^2\}$。解释大的 λ，并计算 $\tau \to 0$ 和 $\tau \to \infty$ 时的极限。

习题 2.13 (B 类)**.** 计算 (w, y) 的联合协方差的三个分块，并应用定理 2.10 得出命题 2.11。然后验证 $\operatorname{Cov}(w \mid y)$ 不依赖于 y，并说明这对观测到出人意料的 y 的实验者意味着什么。

习题 2.14 (B 类)**.** 设 $Y \sim \mathcal{N}(0, 1)$，$X = Y^2 - 1$。证明 $\operatorname{Cov}(X, Y) = 0$，所以 X 到 $\operatorname{span}\{1, Y\}$ 的投影为 0，均方误差为 2。计算 $\mathbb{E}[X \mid Y]$ 及其误差。定理 2.9 的哪个假设不成立?

2.6 * 岭估计量的两种形式

本节不在课堂讲授。命题 2.11 求逆的是 $p \times p$ 矩阵，得到它的推导求逆的则是 $n \times n$ 矩阵。

习题 2.15 (C 类)**.** 证明当 $\lambda > 0$ 时，

$$(H^\top H + \lambda I_p)^{-1} H^\top = H^\top (HH^\top + \lambda I_n)^{-1},$$

并由此推得当 $p \gg n$ 时，岭回归的代价是 $O(n^3)$ 而非 $O(p^3)$。然后在 $n < p$ 且 H 行满秩时令 $\tau \to \infty$，证明后验均值收敛到 $H^\top(HH^\top)^{-1} y$，即 $Hw = y$ 的最小范数解。解释为何两种形式中只有一种能直接看出此极限。

译注： 这里的 $O(n^3)$ 与 $O(p^3)$ 比较已形成的稠密线性系统的分解代价。若从显式 $n \times p$ 矩阵 H 开始，通常形成 $HH^\top$ 还需 $O(n^2 p)$，再乘 $H^\top$ 需 $O(np)$；因此不是任意 $p \gg n$ 情形端到端均为 $O(n^3)$。

2.7 * 去噪就是条件化

本节不在课堂讲授。设 X 是 $\mathbb{R}^d$ 中满足 $\mathbb{E}|X|^2 < \infty$ 的随机向量，不假设其为高斯向量，并令

$$Y = X + \sigma\xi, \qquad \xi \sim \mathcal{N}(0, I_d) \text{ 且与} X \text{ 独立}.$$

则 Y 的密度为 $p_Y(y) = \mathbb{E}[\varphi_\sigma(y - X)]$，其中 φ_σ 是 $\mathcal{N}(0, \sigma^2 I_d)$ 的密度。函数 $\nabla \log p_Y$ 称为 Y 的得分函数。

命题 2.16 (Tweedie 公式)**.**

$$\mathbb{E}[X \mid Y] = Y + \sigma^2 \nabla \log p_Y(Y).$$

证明. 由引理 2.3(ii)，只需对每个光滑紧支撑函数 f 证明 $\mathbb{E}[\langle X - Y - \sigma^2 \nabla \log p_Y(Y), f(Y)\rangle] = 0$。

给定 X 时向量 ξ 是标准高斯向量，因此逐坐标使用 $\mathbb{E}[\eta F(\eta)] = \mathbb{E}[F'(\eta)]$（引理 1.10）得到

$$\mathbb{E}[\langle Y - X, f(Y)\rangle] = \sigma \mathbb{E}[\langle \xi, f(X + \sigma\xi)\rangle] = \sigma^2 \mathbb{E}[\nabla \cdot f(Y)].$$

对 y 分部积分，

$$\begin{aligned} \mathbb{E}[\nabla \cdot f(Y)] &= \int (\nabla \cdot f) p_Y \, dy = -\int \langle f(y), \nabla p_Y(y)\rangle \, dy \\ &= -\mathbb{E}[\langle f(Y), \nabla \log p_Y(Y)\rangle]. \end{aligned}$$

□

习题 2.17 (A 类)**.** 取 $X \sim \mathcal{N}(0, \tau^2 I_d)$。计算 p_Y 和 $\nabla \log p_Y$，并检验命题 2.16 给出 $\mathbb{E}[X \mid Y] = \frac{\tau^2}{\tau^2 + \sigma^2} Y$，与定理 2.9 一致。这两种推导中哪一个用到了 X 的高斯性?

习题 2.18 (B 类)**.** 证明 p_Y 光滑且 $\nabla p_Y(y) = \mathbb{E}[\nabla \varphi_\sigma(y - X)]$，并说明分部积分的边界项消失需要什么条件。然后证明在引理 2.3(ii) 中只用光滑紧支撑 f 作检验就足够。

习题 2.19 (C 类)**.** 去噪器是使 $\mathbb{E}|X - D(Y)|^2$ 在所有函数 $D : \mathbb{R}^d \to \mathbb{R}^d$ 上最小的 D。证明 D 和 $\nabla \log p_Y$ 显式地相互决定，并推得对数据对 $(X, X + \sigma\xi)$ 用最小二乘拟合去噪器，即可估计 Y 的分布的得分函数；这一过程既不需要 p_X，也不需要似然。