

现代机器学习中的概率

ORF 526 课程材料译稿

第 1–2 讲习题解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

解答

编号与讲义一致。C 类习题的关键思路置于框中；掌握思路后其余部分是常规推导，这也正是分类的含义。

第 1–2 讲：定义、存在性与独立性（第 1.2–1.4 节）

1.8（A）

(a) $\mu\cdot\xi=\xi_1-\xi_2$ 且 $\xi^\top\Sigma\xi=2\xi_1^2+2\xi_1\xi_2+\xi_2^2$，故

$$\varphi_X(\xi)=\exp\!\left[-i(\xi_1-\xi_2)-\tfrac{1}{2}(2\xi_1^2+2\xi_1\xi_2+\xi_2^2)\right].$$

命题 1.4 给出 $\partial_1\partial_2\varphi_X(0)=-\Sigma_{12}-\mu_1\mu_2=-1+1=0=-\mathbb{E}[X_1X_2]$，故 $\mathbb{E}[X_1X_2]=0$——只有减去均值后才不相关。[1]

(b) 取 $B=\begin{pmatrix}1&1\\1&-1\end{pmatrix}$，定理 1.5 给出 $BX\sim\mathcal{N}((0,2),B\Sigma B^\top)$，其中 $B\Sigma B^\top=\begin{pmatrix}5&1\\1&1\end{pmatrix}$。故 $X_1+X_2\sim\mathcal{N}(0,5)$、$X_1-X_2\sim\mathcal{N}(2,1)$，且协方差为 $1\neq0$，因此不独立。

(c) $\mathrm{Cov}(X_1+X_2,X_1-X_2)=\Sigma_{11}-\Sigma_{22}$。由于二者联合高斯，由定理 1.16，独立等价于 $\Sigma_{11}=\Sigma_{22}$：不论相关性如何，方差相等即可。$v\cdot X$ 为常数当且仅当 $\mathrm{Var}(v\cdot X)=v^\top\Sigma v=0$，即 $v\in\ker\Sigma$，所以存在这样的非零 v 当且仅当 Σ 奇异。

1.9（C）

> 对变换应用不变性，把 $(\xi_1,\xi_2,0,\dots,0)$ 旋转到 $(\sqrt{\xi_1^2+\xi_2^2},0,\dots,0)$。独立性使 φ_X 成为乘积；旋转把此乘积变成关于 ξ^2 的 Cauchy 函数方程。

独立性给出 $\varphi_X(\xi)=\prod_j\varphi_1(\xi_j)$，其中 φ_1 是各坐标共同的变换。不变性对所有正交矩阵 O 给出 $\varphi_X(O^\top\xi)=\varphi_{OX}(\xi)=\varphi_X(\xi)$，故 φ_X 仅是 $|\xi|$ 的函数。取 $O=\mathrm{diag}(-1,1,\dots,1)$，得到 $X_1\overset{d}{=}-X_1$，故 φ_1 为实偶函数。

取 $\xi=(\xi_1,\xi_2,0,\dots,0)$，旋转到 $(r,0,\dots,0)$，其中 $r=\sqrt{\xi_1^2+\xi_2^2}$。由 $\varphi_1(0)=1$，两乘积相等：

$$\varphi_1(\xi_1)\varphi_1(\xi_2)=\varphi_1\!\left(\sqrt{\xi_1^2+\xi_2^2}\right).$$

令 $F(u)=\varphi_1(\sqrt{u})$，$u\geq0$，则 $F(u)F(v)=F(u+v)$、$F(0)=1$，且 F 连续。又 $F(u)=F(u/2)^2\geq0$；若某个 $F(u_0)=0$，则对每个 k 均有 $F(u_02^{-k})=0$，与连续性及 $F(0)=1$ 矛盾。因此 $F>0$，$\log F$ 连续且可加，故为线性函数，$F(u)=e^{-cu/2}$。由 $|F|\leq1$ 得 $c\geq0$，于是

$$\varphi_1(\xi)=e^{-c\xi^2/2},\qquad\varphi_X(\xi)=e^{-c|\xi|^2/2},\qquad X\sim\mathcal{N}(0,cI_d).$$

这里从未使用矩条件；方差最终作为常数 c 出现。$d\geq2$ 的作用在于：只有一个坐标时无从旋转，而 $O(1)=\{\pm1\}$ 只说明 X_1 对称。

---

[1] 此句按原文保留。本例 $\mathbb{E}[X_1X_2]=0$，但 $\mathrm{Cov}(X_1,X_2)=0-(1)(-1)=1$；减去均值后协方差仍为 1，故原文关于不相关的说法不成立。

1.14（A） 对 $Z\sim\mathcal{N}(0,I_d)$，

$$\widehat{f}(\xi)=\int f(x)e^{-ix\cdot\xi}\,dx=\mathbb{E}e^{-iZ\cdot\xi}=\prod_j e^{-\xi_j^2/2}=e^{-|\xi|^2/2},$$

这里最后一步用了 d 次引理 1.10。反演时每个坐标积分由同一引理给出

$$\int_{\mathbb{R}} e^{-\xi^2/2}e^{ix\xi}\,d\xi=\sqrt{2\pi}\,\mathbb{E}e^{-i(-x)g}=\sqrt{2\pi}e^{-x^2/2}.$$

将 d 个积分相乘并除以 $(2\pi)^d$，得到 $(2\pi)^{-d/2}e^{-|x|^2/2}=f(x)$。由于 $\widehat{f}=(2\pi)^{d/2}f$，标准高斯密度是变换的本征函数。

1.15（B）

(a) $Z=A^{-1}(X-\mu)$，故 $p_X(x)=p_Z(A^{-1}(x-\mu))|\det A|^{-1}$。由于 $\Sigma^{-1}=(AA^\top)^{-1}=A^{-\top}A^{-1}$，有 $|A^{-1}(x-\mu)|^2=(x-\mu)^\top\Sigma^{-1}(x-\mu)$，且 $|\det A|=(\det\Sigma)^{1/2}$。二者均仅依赖 Σ，故公式与所选平方根无关；具体地，任意两个平方根相差 $A'=AO$，O 正交，且 $|\det A'|=|\det A|$。

(b) 若 Σ 奇异，取非零 $v\in\ker\Sigma$。则 $\mathrm{Var}(v\cdot X)=v^\top\Sigma v=0$，故 X 位于超平面 $\{x:v\cdot x=v\cdot\mu\}$。任意密度在超平面上的积分为零，故 X 无密度。

1.18（B）

(a) $X+Y=(1+\epsilon)g$：$\epsilon=-1$ 时为零，$\epsilon=1$ 时为 $2g$，故为 δ_0 与 $\mathcal{N}(0,4)$ 的等权混合，在原点有质量 $1/2$ 的原子。高斯分布要么是点质量，要么有密度；该分布两者都不是。

(b) $sX+uY=(s+u\epsilon)g$ 是 $\mathcal{N}(0,(s+u)^2)$ 与 $\mathcal{N}(0,(s-u)^2)$ 的等权混合，在 $\xi=(s,u)$ 处的变换为 $\frac12e^{-(s+u)^2/2}+\frac12e^{-(s-u)^2/2}$。它仅在 $(s+u)^2=(s-u)^2$，即 $su=0$ 时为高斯。因此推论 1.7 的假设仅在两条坐标轴成立，这正是边缘分布高斯的陈述；离开坐标轴便不成立，故并不与该推论矛盾。

(c) 没有密度：(X,Y) 位于 $\{y=x\}\cup\{y=-x\}$，而密度在两条直线上的积分为零。

熵与高斯分布的极大熵性质（第 1.5* 节）

1.19（A）

(a) $H(q)=-q\log q-(1-q)\log(1-q)$ 关于 $q=1/2$ 对称，端点为零，在 $1/2$ 取最大值 $\log 2$。n 点上的均匀分布的熵为 $\log n$。

(b) 分别为 $\log a$、$1-\log\lambda$、$\frac12\log(2\pi e\sigma^2)$。当 $a<1$ 时 $[0,a]$ 上均匀分布的 $h=\log a<0$。离散熵非负，因为 $p\in(0,1]$ 时 $-p\log p\geq 0$；密度则可以超过 1，正是这一点打破了该结论。

(c) $p_Y(y)=|a|^{-1}p_X(y/a)$。换元 $x=y/a$ 得

$$h(Y)=-\int p_X(x)[\log p_X(x)-\log|a|]dx=h(X)+\log|a|.$$

1.20（B） 由 Jensen 不等式，$-D(p\|q)=\int p\log(q/p)\le\log\int q=0$，等号当且仅当 q/p 为常数，因而恒为 1。取 n 点上的均匀分布 $q\equiv 1/n$，则 $0\le D(p\|q)=-H(p)+\log n$，等号仅在 $p=q$ 时成立。变换 $X\mapsto aX$ 时两个密度获得相同因子 $|a|^{-1}$，且作相同换元，所以 $D(p\|q)$ 不变。

1.21（B） $\log q(x)=-\frac{d}{2}\log(2\pi)-\frac{1}{2}\log\det\Sigma-\frac{1}{2}(x-\mu)^\top\Sigma^{-1}(x-\mu)$ 是 x 的二次函数，因此 $\int p\log q$ 是 $\int p$、$\int x_i p$、$\int x_i x_j p$ 的固定线性函数。均值与协方差匹配给出 $\int p\log q=\int q\log q=-h(q)$，故 $0\le D(p\|q)=-h(p)+h(q)$。又 $\mathbb{E}[(X-\mu)^\top\Sigma^{-1}(X-\mu)]=\operatorname{tr}(\Sigma^{-1}\Sigma)=d$，所以 $h(q)=\frac{1}{2}\log((2\pi e)^d\det\Sigma)$。

1.22（C）

译注：以下熵的加减及次可加性论证须在所涉微分熵有限或已明确良定义的条件下使用，不能对未定义的熵或 $\infty-\infty$ 作代数运算。仅有密度并不自动满足这一要求。

> $(x,y)\mapsto((x+y)/\sqrt{2},(x-y)/\sqrt{2})$ 是正交变换，其雅可比为 1[a]，故保持联合微分熵。
>
> [a]原文如此表述。这个正交变换的行列式为 -1，绝对雅可比为 1；熵保持使用的是后者，故该结论不受影响。

令 $U=(X+Y)/\sqrt{2}$、$V=(X-Y)/\sqrt{2}$。由独立性 $h(U,V)=h(X,Y)=2h(X)$。次可加性 $h(U,V)\le h(U)+h(V)$ 来自对联合密度与边缘密度之积应用习题 1.20。由对称性 $(X,Y)\overset{d}{=}(X,-Y)$，故 $V\overset{d}{=}U$。连起来得 $2h(X)\le 2h(U)$。

1.23（C）

> 高斯情形的证明从未使用高斯性，而是使用了 $\log q$ 为受约束函数的仿射组合，因此 $\int p\log q$ 仅由约束确定。

$\log q=\sum_m\lambda_m T_m-\log Z$，所以对任何可行的 p，

$$0\le D(p\|q)=-h(p)-\sum_m\lambda_m c_m+\log Z,$$

后两项不依赖 p。取 $p=q$ 可知它们等于 $h(q)$；相减得到 $h(p)\le h(q)$，等号当且仅当 $p=q$。（无需假设 $h(p)$ 可积：$-\infty$ 时结论显然，$+\infty$ 则被 $D(p\|q)\ge 0$ 排除。）例子包括：$[0,a]$ 上无约束得到常数 q；$[0,\infty)$ 上 $T_1(x)=x$ 得到指数分布；T 为 x_i, x_ix_j 得到 $\mathcal{N}(\mu,\Sigma)$。

假设并非自动成立：在 $S=\mathbb{R}$ 上仅约束均值时，$e^{\lambda x}$ 不可积；这符合预期，因为每个 $\mathcal{N}(0,\sigma^2)$ 均可行，而 $h=\frac{1}{2}\log(2\pi e\sigma^2)\to\infty$。“$q$ 是密度”正是排除这一情况的条件；假设其存在就已经假设了实质内容。

塔式性质（第 2.3 节）

2.6（A） 推论 2.5 为 $\operatorname{Var}X=\mathbb{E}[\operatorname{Var}(X\mid Y)]+\operatorname{Var}(\mathbb{E}[X\mid Y])$，第一项非负。等号成立当且仅当 $\operatorname{Var}(X\mid Y)=0$，即 X 是 Y 的函数。全部方差恰好位于第一项当且仅当 $\mathbb{E}[X\mid Y]$ 为常数，

X 与 Y 独立时便是如此。

2.7（B） 给定 J 时，X 的均值为 ± 1、方差为 σ^2，故 $\mathrm{Var}(X \mid J) = \sigma^2$ 恒成立，$\mathbb{E}[\mathrm{Var}(X \mid J)] = \sigma^2$；而 $\mathbb{E}[X \mid J] = \pm 1$，$\mathrm{Var}(\mathbb{E}[X \mid J]) = 1$。总方差为 $\sigma^2 + 1$。直接计算得 $\mathbb{E}X = 0$，且

$$\mathbb{E}X^2 = \mathbb{E}[\mathbb{E}(X^2 \mid J)] = \mathbb{E}[\sigma^2 + 1] = \sigma^2 + 1.$$

第二部分中 W 是 $X_1, \ldots, X_n$ 的函数，因此以这些 X_i 为条件更精细；命题 2.4 给出

$$\mathbb{E}[V \mid W] = \mathbb{E}[\mathbb{E}[V \mid X_1, \ldots, X_n] \mid W] = \mathbb{E}[-W/n \mid W] = -W/n.$$

最后一步是因为 W 的函数在给定 W 下的条件期望就是自身。这一性质称为塔式性质。

贝叶斯线性模型与第 2.6*、2.7* 节

译注： 本段高斯密度、噪声倒数及得分字典使用非退化噪声 $\sigma \neq 0$，通常取 $\sigma > 0$；$\lambda = \sigma^2/\tau^2$ 还要求 $\tau \neq 0$。所列 $\tau \to 0, \infty$ 是从正参数出发的极限，涉及无正则化逆矩阵时仍须满足相应秩条件。零噪声或零先验不能直接代入含除法的密度公式。

2.12（A）

(a) $p(y \mid w) = (2\pi\sigma^2)^{-n/2} e^{-\|y - Hw\|^2/(2\sigma^2)}$，故 $-\log p = \|y - Hw\|^2/(2\sigma^2) + (n/2)\log(2\pi\sigma^2)$，关于 w 的最小值给出最小二乘拟合。选择平方误差就相当于断言噪声是高斯、同方差且在各观测之间独立；大多数选择平方误差的人并未作出这种断言，这正是要点。

(b) 后验密度正比于 $\exp[-\|y - Hw\|^2/(2\sigma^2) - \|w\|^2/(2\tau^2)]$，故其最大化等价于最小化 $\|y - Hw\|^2 + \lambda\|w\|^2$，其中 $\lambda = \sigma^2/\tau^2$。大的 λ 对应噪声较大的数据和较确信的先验，因而收缩强；$\tau \to 0$ 得 $\widehat{w} = 0$，$\tau \to \infty$ 得最小二乘。

2.13（B） (w, y) 是 (w, ϵ) 的线性像，因此联合高斯，其协方差块为

$$\Sigma_{ww} = \tau^2 I_p, \quad \Sigma_{wy} = \mathbb{E}[w(Hw + \sigma\epsilon)^\top] = \tau^2 H^\top, \quad \Sigma_{yy} = \tau^2 HH^\top + \sigma^2 I_n.$$

定理 2.10 直接给出两条公式。$\mathrm{Cov}(w \mid y)$ 不含 y：数据改变估计，却不改变不确定度。具体而言，出乎意料的 y 会移动后验均值，但误差条完全不变；这是高斯模型的特殊性质，通常不成立。

译注： 这里说的是给定模型和观测设置下，后验协方差不依赖实际观测值 y；不是说加入观测前后的不确定度相同。

2.14（B） $\mathrm{Cov}(X, Y) = \mathbb{E}[(Y^2 - 1)Y] = \mathbb{E}Y^3 = 0$，故最佳线性预测为零，误差为 $\mathrm{Var}\, X = \mathrm{Var}(Y^2) = 2$。这里 X 本身是 Y 的函数，所以 $\mathbb{E}[X \mid Y] = Y^2 - 1 = X$，误差为零。失效的假设是 (X, Y) 联合高斯——X 本身就不是高斯变量——因此定理 2.9 不适用，条件均值也不是线性的。

2.15（C）

> $H^\top(HH^\top+\lambda I_n)=(H^\top H+\lambda I_p)H^\top$：展开一行即可。再乘以两个逆矩阵。

两边均为 $H^\top HH^\top+\lambda H^\top$。左乘 $(H^\top H+\lambda I_p)^{-1}$，右乘 $(HH^\top+\lambda I_n)^{-1}$，便得到恒等式。右侧形式求逆的是 $n\times n$ 矩阵，因此计算成本为 $O(n^3)$；这就是核技巧，也解释了高斯过程回归为何可行。

译注：这里的 $O(n^3)$ 与 $O(p^3)$ 比较已形成的稠密线性系统的分解代价。若从显式 $n\times p$ 矩阵 H 开始，通常形成 $HH^\top$ 还需 $O(n^2p)$，再乘 $H^\top$ 需 $O(np)$；因此不是任意 $p\gg n$ 情形端到端均为 $O(n^3)$。

当 $\tau\to\infty$，有 $\lambda\to 0$；在 $H^\top(HH^\top+\lambda I_n)^{-1}y$ 中，极限是良性的，因为 $HH^\top$ 为 $n\times n$ 且可逆：

$$\mathbb{E}[w\mid y]\longrightarrow H^\top(HH^\top)^{-1}y,$$

这正是 $Hw=y$ 的最小范数解。另一形式的极限是 $0\cdot\infty$，这也是该题为 C 类而不是计算题的原因。

2.17（A） (X,ξ) 联合高斯，因此由第 1–2 讲定理 1.5，$Y=X+\sigma\xi\sim\mathcal{N}(0,(\tau^2+\sigma^2)I_d)$。故 $\log p_Y(y)=c-|y|^2/[2(\tau^2+\sigma^2)]$，$\nabla\log p_Y(y)=-y/(\tau^2+\sigma^2)$，命题 2.16 给出

$$\mathbb{E}[X\mid Y=y]=y-\frac{\sigma^2}{\tau^2+\sigma^2}y=\frac{\tau^2}{\tau^2+\sigma^2}y.$$

定理 2.9 给出 $\Sigma_{XY}\Sigma_{YY}^{-1}y=\tau^2 I((\tau^2+\sigma^2)I)^{-1}y$，结果相同。只有第二种推导使用了 X 的高斯性；第一种推导中，高斯性仅用于获得 p_Y 的闭式表达。

2.18（B） $p_Y(y)=\mathbb{E}[\phi_\sigma(y-X)]$。$\phi_\sigma$ 的每阶导数均有界，并且对于紧集中的 y，该界关于 X 一致；故控制收敛定理允许任意阶导数移入期望，$p_Y\in C^\infty$，且 $\nabla p_Y(y)=\mathbb{E}[\nabla\phi_\sigma(y-X)]$。

第二次分部积分 $\int\nabla f\,p_Y=-\int f\nabla p_Y$ 要求无穷远处 $fp_Y\to 0$。取光滑紧支撑 f 可使边界项直接消失，且这已足够：此类 f 在 $L^2(p_Y)$ 中稠密，因此与它们正交便与引理 2.3(ii) 的全部竞争者正交。这两步都可行是因为 Y 是与高斯分布的卷积；任意 Y 未必有密度，更不必说可微密度。

2.19（C）

> Tweedie 公式是字典：它给出最优去噪器与得分函数之间逐点的显式双射，因此得到任意一者就得到另一者。

由定义 2.2，在全部 D 上的最小二乘解为 $D(y)=\mathbb{E}[X\mid Y=y]$；命题 2.16 给出 $D(y)=y+\sigma^2\nabla\log p_Y(y)$，故

$$\nabla\log p_Y(y)=\frac{D(y)-y}{\sigma^2},$$

反之亦然。两个方向均未提及 p_X。

译注：最小二乘只确定 D 的 p_Y-几乎处处等价类；改变单个零测点的值不改变风险，却会破坏该点的得分等式。这里的逐点对应须选取自然版本 $D(y) = y + \sigma^2 \nabla \log p_Y(y)$ $(\sigma \neq 0)$，或将等式理解为几乎处处成立。

拟合 D 只需样本对 $(X, X + \sigma\xi)$，可通过对 X 的样本加噪声生成；既不需要 p_X 也不需要归一化常数。模块 II.11 在每个噪声水平 σ 使用得分函数以逆转加噪过程。