

现代机器学习中的概率

ORF 526 课程材料译稿

第 3–4 讲：中心极限定理（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 高斯分布为何出现，以及通过替换证明中心极限定理

第 3、4 讲：中心极限定理
替换、Lindeberg 条件与 Stein 方法。

纲要： 最大熵 ⟶ 为什么是高斯分布 ⟶ 什么是依分布极限 ⟶ 每次替换一个求和项 ⟶ 中心极限定理与 Lindeberg 条件；
$\mathbb{E}[Wf(W)] = \mathbb{E}[f'(W)]$ ⟶ 向量与矩阵形式 ⟶ Stein 方程 ⟶ 带收敛速率的中心极限定理 ⟶ 对 Poisson 分布使用同一论证。
阅读指南： 带星号的节不在课堂讲授，其内容完整且属于考试范围。习题分为 A、B、C 三类，每周小测各出一题。每节末尾的方框列出需上交的习题；其余均为题库，供选做且属于考试范围，但无需上交。

问题： 在所有分布中，为什么出现的偏偏是高斯分布?

1.1 记号

全文中 $X_1, X_2, \ldots$ 独立同分布，均值为 0、方差为 1，并令

$$S_n := \frac{1}{\sqrt{n}} \sum_{i=1}^{n} X_i.$$

上述归一化使得对每个 n 都有 $\mathrm{Var}(S_n) = 1$。记 $g \sim \mathcal{N}(0,1)$，其分布为 γ。

来自第 1–2 讲的第 1.5* 节

对 $\mathbb{R}$ 上具有密度 p 的随机变量 X，微分熵为 $h(X) = -\int p \log p$，X 相对于 γ 的相对熵为 $D(X\|\gamma) = \int p \log(p/\varphi)$，其中 φ 是标准正态密度。两者都可能为 $+\infty$；X 无密度时，h 未定义。

1.2 “收敛到高斯分布”的含义

S_n 本身不收敛到一个随机变量；收敛的是它的分布，我们用函数对其进行检验。

定义 1.1 (依分布收敛)**.** 对 $\mathbb{R}^k$ 中的随机向量，$X_n \Rightarrow X$ 表示对每个有界连续的 $f : \mathbb{R}^k \to \mathbb{R}$，均有 $\mathbb{E}f(X_n) \to \mathbb{E}f(X)$。

分布函数在跳跃点不一定收敛：若 $X_n \equiv 1/n$ 且 $X \equiv 0$，则 $X_n \Rightarrow X$，但对每个 n 都有 $F_n(0) = 0$，而 $F(0) = 1$。

光滑函数 f 可以作 Taylor 展开，而 $1_{(-\infty,z]}$ 不能，因此下文的证明只用光滑函数检验。这已经足够。

引理 1.2. 假设对每个 $f \in C^3(\mathbb{R})$，只要 f, f', f'', f''' 均有界，就有 $\mathbb{E}f(X_n) \to \mathbb{E}f(X)$。则在 F_X 的每个连续点 z 处，$F_{X_n}(z) \to F_X(z)$。

证明. 固定这样的 z 和 $\delta>0$。取光滑函数 $\psi:\mathbb{R}\to[0,1]$，在 $(-\infty,0]$ 上为 1，在 $[1,\infty)$ 上为 0，并令

$$u_+(x)=\psi\left(\frac{x-z}{\delta}\right),\qquad u_-(x)=\psi\left(\frac{x-z+\delta}{\delta}\right).$$

两者均属于上述检验函数类，且

$$1_{(-\infty,z-\delta]}\le u_-\le 1_{(-\infty,z]}\le u_+\le 1_{(-\infty,z+\delta]}.$$

对 X_n 取期望并取极限，

$$F_X(z-\delta)\le \mathbb{E}u_-(X)=\lim_n \mathbb{E}u_-(X_n)\le \liminf_n F_{X_n}(z),$$
$$\limsup_n F_{X_n}(z)\le \lim_n \mathbb{E}u_+(X_n)=\mathbb{E}u_+(X)\le F_X(z+\delta).$$

令 $\delta\downarrow 0$，并利用 F_X 在 z 处的连续性。 □

对于光滑 f 的收敛速率不是概率的收敛速率；见第 2.3 节。

习题 1.3 (C 类)**.** 设 X_n, X 是 $\mathbb{R}^k$ 中的随机向量，且对每个直到三阶的导数均有界的 $f\in C^3(\mathbb{R}^k)$，都有 $\mathbb{E}f(X_n)\to\mathbb{E}f(X)$。证明 $X_n\Rightarrow X$。这样的 f 既非光滑函数，也不一定紧支撑；依次补救这两个缺陷，并注意假设本身已经限制了 X_n 在远处可以放置的概率质量。

1.3 直观答案

第 1–2 讲第 1.5* 节给出两个事实。第一，在固定方差时，高斯分布使熵最大：只要 $\mathrm{Var}(X)=1$，就有 $h(X)\le h(g)$。第二，对对称的独立同分布随机变量 X,Y，

$$h\left(\frac{X+Y}{\sqrt{2}}\right)\ge h(X),$$

因为 $(x,y)\mapsto((x+y)/\sqrt{2},(x-y)/\sqrt{2})$ 是正交变换，正交变换保持微分熵，而熵满足次可加性。

由于对两个独立副本有 $S_{2^k}=\frac{1}{\sqrt{2}}(S'_{2^{k-1}}+S''_{2^{k-1}})$，$h(S_{2^k})$ 随 k 增大而递增且从不超过 $h(g)$。所以它收敛，而最大化者是极限的唯一候选。

译注：以上保留原文的启发式说法。在单位有限方差且有密度的设定下，$h(X)\le h(g)<\infty$，故 h 不会为 $+\infty$，但可为 $-\infty$；一般熵运算仍需良定义。所示和差论证另用了对称性，仅中心化和单位方差并不够。即使熵单调有界，也不能单凭这一点辨认分布极限或证明中心极限定理；下面引用的定理是额外结果，此处未独立核验其文献证明。

1.4 熵形式的中心极限定理

定理 1.4 (Barron，1986)**.** 若对某个 m 有 $D(S_m\|\gamma)<\infty$，则 $D(S_n\|\gamma)\to 0$；等价地，$h(S_n)\to h(g)$。

定理 1.5 (Artstein–Ball–Barthe–Naor，2004)**.** $h(S_n)$ 随 n 递增，而不限于 n 为 2 的幂时。

我们不证明这两个定理。

例 1.6 (熵形式的中心极限定理无法说明抛硬币情形)**.** 令 $X_i = \pm 1$ 各以概率 $1/2$ 取值。则对每个 n，S_n 都支撑于有限集合，因此它没有密度，$h(S_n)$ 未定义，对每个 m, n 均有 $D(S_n\|\gamma) = \infty$。Barron 定理的假设始终不成立。

经典中心极限定理仍对 ± 1 成立，因此我们需要一个涵盖例 1.6 的证明。

1.5 Lindeberg 的替换论证

定理 1.7 (中心极限定理)**.** 进一步假设 $\mathbb{E}|X_1|^3 < \infty$。则对每个三阶导数有界的 $f \in C^3(\mathbb{R})$，

$$\big|\mathbb{E}f(S_n) - \mathbb{E}f(g)\big| \le \frac{\|f'''\|_\infty}{6\sqrt{n}}\big(\mathbb{E}|X_1|^3 + \mathbb{E}|g|^3\big).$$

证明. 取 $g_1, \dots, g_n$ 为独立同分布的标准高斯变量，且与各 X_i 独立，并构造插值：

$$Z_k = \frac{1}{\sqrt{n}}(g_1 + \cdots + g_k + X_{k+1} + \cdots + X_n), \qquad k = 0, \dots, n,$$

于是 $Z_0 = S_n$，$Z_n \sim \mathcal{N}(0,1)$。由望远镜求和，

$$\mathbb{E}f(S_n) - \mathbb{E}f(g) = \sum_{k=1}^{n}\big(\mathbb{E}f(Z_{k-1}) - \mathbb{E}f(Z_k)\big).$$

固定 k，记 $W_k = \frac{1}{\sqrt{n}}(g_1 + \cdots + g_{k-1} + X_{k+1} + \cdots + X_n)$，它与 X_k、g_k 均独立。于是 $Z_{k-1} = W_k + X_k/\sqrt{n}$、$Z_k = W_k + g_k/\sqrt{n}$。Taylor 定理给出

$$f(W_k + u) = f(W_k) + uf'(W_k) + \tfrac{u^2}{2}f''(W_k) + R(u), \qquad |R(u)| \le \frac{\|f'''\|_\infty}{6}|u|^3.$$

对两个展开取期望并相减。常数项抵消；一次项因 W_k 与 X_k, g_k 独立且后两者均值均为 0 而抵消；二次项因二者方差均为 1 而抵消。只剩余项：

$$\big|\mathbb{E}f(Z_{k-1}) - \mathbb{E}f(Z_k)\big| \le \frac{\|f'''\|_\infty}{6n^{3/2}}\big(\mathbb{E}|X_k|^3 + \mathbb{E}|g_k|^3\big).$$

对 n 项求和即得结论。 □

证明只使用了 Taylor 定理，特别地，它涵盖 $X_i = \pm 1$ 的情况。结合引理 1.2，对每个 z 有 $\mathbb{P}(S_n \le z) \to \Phi(z)$，其中 Φ 是标准正态分布函数。

经典论证——展开 $\varphi_{X_1}(t/\sqrt{n})$ 并取 n 次幂——在第 1.9* 节中给出。

1.6 证明实际需要什么

上述论证从未用到 X_i 同分布，也未用到它们是一维的：同样的替换配合多元 Taylor 展开给出多维中心极限定理。它确实用到的是，没有单个求和项占据很大一部分方差。

定义 1.8 (Lindeberg 条件)**.** 设 $\{X_{n,i}\}_{i \le k_n}$ 为逐行独立的三角阵列，且

$$\mathbb{E}X_{n,i} = 0, \qquad s_n^2 = \sum_{i \le k_n}\operatorname{Var}(X_{n,i}), \qquad k_n \to \infty, \qquad s_n \to \infty.$$

若对每个 $\varepsilon > 0$，

$$L_n(\varepsilon) := \frac{1}{s_n^2}\sum_i \mathbb{E}\big[X_{n,i}^2 \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}}\big] \longrightarrow 0,$$

则称该阵列满足 Lindeberg 条件。

统一作归一化：

$$Y_{n,i}=\frac{X_{n,i}}{s_n},\qquad \sigma_{n,i}^2=\operatorname{Var}(Y_{n,i}),\qquad T_n=\sum_{i\le k_n}Y_{n,i},$$

于是 $\sum_i \sigma_{n,i}^2=1$，且 $L_n(\varepsilon)=\sum_i \mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]$。

定理 1.9 (Lindeberg)**.** 在 Lindeberg 条件下，$T_n\Rightarrow\mathcal{N}(0,1)$。

证明. 设 $f\in C^3(\mathbb{R})$，f'' 与 f''' 有界。Taylor 定理展开到二阶和三阶，一致地对 w 给出

$$\begin{aligned} f(w+u)&=f(w)+uf'(w)+\tfrac{u^2}{2}f''(w)+R(u),\\ |R(u)|&\le \min\left(\frac{\|f'''\|_\infty}{6}|u|^3,\ \|f''\|_\infty u^2\right). \end{aligned}\tag{1}$$

第二个界由某个 $\theta\in(0,1)$ 对应的 $R(u)=\frac{u^2}{2}(f''(w+\theta u)-f''(w))$ 得到；它少一个 u 的幂，且不涉及 f'''。

在 ε 处分割 $Y_{n,i}$ 的二阶矩，对每个 i 和每个 $\varepsilon>0$，

$$\sigma_{n,i}^2=\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|\le\varepsilon\}}]+\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]\le\varepsilon^2+L_n(\varepsilon).\tag{2}$$

故对每个 ε 都有 $\limsup_n \max_i \sigma_{n,i}^2\le\varepsilon^2$，即 $\max_i\sigma_{n,i}\to 0$。

取 $g_{n,i}\sim\mathcal{N}(0,\sigma_{n,i}^2)$，彼此独立且与该阵列独立，于是 $\sum_i g_{n,i}\sim\mathcal{N}(0,1)$。仿照定理 1.7 逐项替换。令

$$W_{n,i}=g_{n,1}+\cdots+g_{n,i-1}+Y_{n,i+1}+\cdots+Y_{n,k_n},$$

它与 $Y_{n,i}$ 和 $g_{n,i}$ 均独立；望远镜求和给出

$$\bigl|\mathbb{E}f(T_n)-\mathbb{E}f(g)\bigr|\le\sum_i\bigl|\mathbb{E}f(W_{n,i}+Y_{n,i})-\mathbb{E}f(W_{n,i}+g_{n,i})\bigr|.$$

用式 (1) 展开两项。$Y_{n,i}$ 与 $g_{n,i}$ 的前两阶矩相同，且两者均与 $W_{n,i}$ 独立，因此常数、一次及二次项逐项抵消，只剩余项。在 Y 一侧，$|Y_{n,i}|\le\varepsilon$ 时使用三次界，$|Y_{n,i}|>\varepsilon$ 时使用二次界：

$$\begin{aligned}\sum_i\mathbb{E}|R(Y_{n,i})|&\le\frac{\|f'''\|_\infty}{6}\varepsilon\sum_i\mathbb{E}[Y_{n,i}^2]+\|f''\|_\infty\sum_i\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]\\&=\frac{\|f'''\|_\infty}{6}\varepsilon+\|f''\|_\infty L_n(\varepsilon).\end{aligned}$$

高斯一侧无需截断：$\mathbb{E}|g_{n,i}|^3=2\sqrt{2/\pi}\,\sigma_{n,i}^3$，且 $\sum_i\sigma_{n,i}^3\le\max_i\sigma_{n,i}$，所以

$$\sum_i\mathbb{E}|R(g_{n,i})|\le\frac{\|f'''\|_\infty}{3}\sqrt{\frac{2}{\pi}}\max_i\sigma_{n,i}.$$

将两边相加并令 $n\to\infty$：由假设 $L_n(\varepsilon)\to 0$，由式 (2) 有 $\max_i\sigma_{n,i}\to 0$，故对每个 $\varepsilon>0$，

$$\limsup_{n\to\infty}\bigl|\mathbb{E}f(T_n)-\mathbb{E}f(g)\bigr|\le\frac{\|f'''\|_\infty}{6}\varepsilon.$$

因此左边为 0。引理 1.2 将其转为依分布收敛。 □

注 1.10 (Feller 条件)**.** 若

$$\max_{i\le k_n}\frac{\operatorname{Var}(X_{n,i})}{s_n^2}=\max_{i\le k_n}\sigma_{n,i}^2\longrightarrow 0,$$

则称该阵列满足 Feller 条件。以下三个精确陈述将它与定义 1.8 联系起来。

(a) Lindeberg 条件蕴含 Feller 条件。这正是式 (2)；也是上面证明中除 $L_n(\varepsilon)\to 0$ 以外唯一使用的条件。

(b) 该蕴含是严格的：习题 1.14 给出满足 Feller 条件但不满足 Lindeberg 条件的阵列。

(c) 逆命题，只作陈述不证明：若 Feller 条件成立且 $T_n\Rightarrow\mathcal{N}(0,1)$，则 Lindeberg 条件成立。

结合定理 1.9，(c) 表明在 Feller 条件下 Lindeberg 条件等价于中心极限定理。这两项合称 Lindeberg–Feller 定理。

注 1.11 (Lyapunov 条件)**.** 实践中常检验一个较粗的条件：若对某个 $\delta>0$，

$$\frac{1}{s_n^{2+\delta}}\sum_{i}\mathbb{E}|X_{n,i}|^{2+\delta}\longrightarrow 0,$$

则 Lindeberg 条件成立：在 $\{|X_{n,i}|>\varepsilon s_n\}$ 上可写 $X_{n,i}^2\le |X_{n,i}|^{2+\delta}/(\varepsilon s_n)^{\delta}$。对独立同分布噪声的加权和 $X_{n,i}=a_{n,i}\xi_i$，若 $\mathbb{E}|\xi_1|^3<\infty$，这给出

$$L_n(\varepsilon)\le\frac{\mathbb{E}|\xi_1|^3}{\varepsilon}\left(\frac{\|a_n\|_3}{\|a_n\|_2}\right)^3,$$

所以只要 $\|a_n\|_3/\|a_n\|_2\to 0$，该和渐近高斯。这一条件失效恰好对应有限个坐标占据 $\|a_n\|_2^2$ 的固定份额。

译注：这条所印定量界使用 $\mathbb{E}\xi_i=0$、$\operatorname{Var}\xi_i=1$。若方差为 $v\in(0,\infty)$，右侧须另除以 $v^{3/2}$（并使用中心化三阶绝对矩）；否则重缩放 ξ_i 会改变右侧而不改变归一化后的 L_n。零方差情形须另行处理。

Lindeberg 条件区分了两个区域：许多小贡献给出高斯分布，少数稀有贡献给出 Poisson 分布。第 1.9^{*} 节计算边界两侧；第 2.4 节证明 Poisson 情形并给出速率。

注 1.12 (极限是普适的，速率不是)**.** 通过模拟得到 S_{30} 与 $\mathcal{N}(0,1)$ 的 Kolmogorov–Smirnov 距离：均匀分布为 0.0014，指数分布为 0.025，±1 为 0.073。极限不依赖于 X_1 的分布；速度则依赖，格点型求和项最慢。

习题 1.13 (A 类)**.** 设 $X_1,X_2,\dots$ 独立同分布，均值为 0、方差 $\sigma^2\in(0,\infty)$，对 $i\le n$ 令 $X_{n,i}=X_i$。证明 $L_n(\varepsilon)=\sigma^{-2}\mathbb{E}[X_1^2\mathbf{1}_{\{|X_1|>\varepsilon\sigma\sqrt{n}\}}]$ 且它趋于 0。使用控制收敛，控制变量为 X_1^2。由此说明定理 1.9 包含不要求三阶矩的定理 1.7。

习题 1.14 (C 类)**.** 设 $X_{n,i}$ $(i\le n)$ 独立，各以概率 $\frac12(1-\frac1n)$ 取值 ±1，各以概率 $\frac{1}{2n}$ 取值 $\pm\sqrt{n}$。证明 $s_n^2=2n-1$，Feller 条件成立，并且对每个 $\varepsilon\le 1/\sqrt{2}$ 有 $L_n(\varepsilon)\to\frac12$。接着计算 $\lim_n\varphi_{T_n}(t)$ 并辨认极限分布。注 1.10(c) 在计算之前就说明极限不可能为 $\mathcal{N}(0,1)$。一半方差位于 ±1，一半位于稀有的 $\pm\sqrt{n}$。

1.7 纪录，以及随机搜索为何趋于平台

定义 1.8 中 $s_n \to \infty$ 的假设有以下推论。

引理 1.15. 若定义 1.8 中的阵列一致有界，即对所有 n, i 都有 $|X_{n,i}| \le C$，则 Lindeberg 条件成立。

证明. 固定 $\varepsilon > 0$。由于 $s_n \to \infty$，当 n 充分大时 $\varepsilon s_n > C$，此时对每个 i，事件 $\{|X_{n,i}| > \varepsilon s_n\}$ 均为空，因此 $L_n(\varepsilon) = 0$。 □

下面的阵列不是同分布求和项之和的重新缩放。设 $X_1, X_2, \dots$ 独立同分布且分布连续，故当 $i \neq j$ 时 $\mathbb{P}(X_i = X_j) = 0$，并令

$$B_i = \mathbf{1}\{X_i > \max(X_1, \dots, X_{i-1})\}, \qquad B_1 = 1,$$

于是 $R_n = \sum_{i \le n} B_i$ 计数前 n 个观测中的纪录，即迄今最大值被改进的次数。

引理 1.16 (Rényi)**.** $B_1, \dots, B_n$ 独立，且 $\mathbb{P}(B_i = 1) = 1/i$。

证明. 两个秩向量。令

$$r_i = \#\{j \le n : X_j \le X_i\}, \qquad \rho_i = \#\{j \le i : X_j \le X_i\},$$

于是 $r \in S_n$ 记录整个样本的相对次序，ρ_i 只记录 X_i 在前 i 个观测中的秩，且 $B_i = \mathbf{1}\{\rho_i = i\}$。注意 $\rho_i \in \{1, \dots, i\}$，故 ρ 取值于

$$C = \{1\} \times \{1, 2\} \times \cdots \times \{1, \dots, n\}.$$

（例如 $n = 3$ 且 $X_2 < X_3 < X_1$ 时，$r = (3, 1, 2)$，$\rho = (1, 1, 2)$，只有 X_1 是纪录。）

第一步：r 在 S_n 上均匀。各 X_i 独立同分布且相等的概率为 0，所以置换样本不改变其分布；因此对所有 $\pi \in S_n$，$\mathbb{P}(r = \pi)$ 相同，而这样的置换共有 $n!$ 个。

第二步：$r \mapsto \rho$ 是 $S_n \to C$ 的双射。两集合都有 $n!$ 个元素，故只需证明映射单射，即可由 ρ 恢复 r。对 n 归纳：由于 $\rho_n = r_n$，最后一个观测在次序中的位置已知。将其删除后，剩下 $X_1, \dots, X_{n-1}$，其秩向量映为 $(\rho_1, \dots, \rho_{n-1})$，因为每个 $i < n$ 的 ρ_i 仅涉及前 i 个观测，故由归纳假设确定。将 X_n 按秩 ρ_n 重新插入即可恢复 r。

第三步：双射将均匀分布映成均匀分布，因此 ρ 在 C 上均匀。乘积集上的均匀分布恰好意味着坐标独立且各自均匀：$\rho_1, \dots, \rho_n$ 独立，ρ_i 在 $\{1, \dots, i\}$ 上均匀。所以 $B_i = \mathbf{1}\{\rho_i = i\}$ 独立，且 $\mathbb{P}(B_i = 1) = 1/i$。 □

定理 1.17 (纪录)**.** 令 $H_n = \sum_{i \le n} 1/i$，$s_n^2 = H_n - \sum_{i \le n} 1/i^2$，则

$$\frac{R_n - H_n}{s_n} \Rightarrow \mathcal{N}(0, 1).$$

证明. 对阵列 $X_{n,i} = B_i - 1/i$ $(i \le n)$ 应用定理 1.9。由引理 1.16，该阵列独立且中心化，$\mathrm{Var}(X_{n,i}) = \frac{1}{i}(1 - \frac{1}{i})$，因而 s_n^2 如上。由于 $s_n^2 \ge H_n - \pi^2/6 \to \infty$ 且 $|X_{n,i}| \le 1$，引理 1.15 给出 Lindeberg 条件。 □

各方差 $\frac{1}{i}(1-\frac{1}{i})$ 彼此不可比，且 s_n 按 $\sqrt{\log n}$ 而非 $\sqrt{n}$ 的量级增长，因此没有任何重新缩放可将 R_n 化为某个 S_m。

注 1.18 (两种情形中的 Bernoulli 阵列)**.** 第 1.6 节的两种情形都是独立 Bernoulli 变量的阵列，只是方差不同。对 $B_{n,i}\sim\text{Bernoulli}(\lambda/n)$ $(i\le n)$，总方差 $\lambda(1-\lambda/n)$ 保持有界，定义 1.8 完全不适用，极限为 Poisson(λ)。对 $B_i\sim\text{Bernoulli}(1/i)$，总方差发散，极限为高斯。假设 $s_n\to\infty$ 区分了两者。

注 1.19 (随机搜索)**.** 对独立抽取的 n 个超参数配置评分，并保留迄今最佳者。当前最佳值被改进的次数正是 R_n，因此其期望为 H_n，涨落量级为 $\sqrt{\log n}$：$\mathbb{E}R_{100}=5.19$、$\mathbb{E}R_{10^4}=9.79$。n 增加一百倍使期望改进次数增加 $\log 100=4.6$。

注 1.20 (一个缓慢的定理)**.** 有效样本量是 $s_n^2\approx\log n$，而非 n，因此误差应为 $1/s_n$ 的量级。$(R_n-H_n)/s_n$ 与 $\mathcal{N}(0,1)$ 的精确 Kolmogorov–Smirnov 距离如下：

n	10^2	10^3	10^4	10^5
KS	0.131	0.106	0.089	0.080
$1/s_n$	0.53	0.41	0.35	0.31

要使误差减半，需将 n 提高到四次方。与注 1.12 类似，R_n 也取格点值。

习题 1.21 (A 类)**.** 设 $B_{n,i}\sim\text{Bernoulli}(p_{n,i})$ $(i\le k_n)$ 相互独立，令 $\sigma_n^2=\sum_i p_{n,i}(1-p_{n,i})$。证明若 $\sigma_n\to\infty$，则

$$\frac{1}{\sigma_n}\sum_i(B_{n,i}-p_{n,i})\Rightarrow\mathcal{N}(0,1).$$

使用引理 1.15，一行即可。注 1.18 中 $p_{n,i}=\lambda/n$ 的阵列在何处不满足假设，其极限又是什么？

习题 1.22 (B 类)**.** 由定理 1.17 推得 $(R_n-\log n)/\sqrt{\log n}\Rightarrow\mathcal{N}(0,1)$。先证明这个工具：若 $Z_n\Rightarrow Z$、$\sup_n\mathbb{E}Z_n^2<\infty$，且确定性数列 $a_n\to1$、$b_n\to0$，则 $a_nZ_n+b_n\Rightarrow Z$。对有界一致连续的 f，在 $|Z_n|\le M$ 处分割，并将远处部分用 $2\|f\|_\infty\mathbb{P}(|Z_n|>M)\le 2\|f\|_\infty M^{-2}\sup_n\mathbb{E}Z_n^2$ 控制。再使用 $H_n-\log n\to\gamma$ 和 $s_n^2/\log n\to1$。为何仅靠引理 1.2 不够？

习题 1.23 (B 类)**.** 依次插入 $1,2,\dots,n$，以循环形式构造 $[n]$ 上的均匀随机置换：元素 i 以概率 $1/i$ 开启一个新循环；否则把它放在已有 $i-1$ 个元素之一的正后方，每种位置概率均为 $1/i$。证明每个置换都来自唯一的选择序列，而每个序列的概率均为 $1/n!$，因此该构造是均匀的。推得循环数 K_n 与 $\sum_{i\le n}\text{Bernoulli}(1/i)$ 同分布，其中各求和项独立，因而

$$\frac{K_n-\log n}{\sqrt{\log n}}\Rightarrow\mathcal{N}(0,1).$$

这就是 Gončarov 定理，该双射与引理 1.16 中的计数论证相同。

1.8 * 初始化时的宽网络

本节不在课堂讲授。固定非线性函数 $\sigma:\mathbb{R}\to\mathbb{R}$，令

$$f_m(x)=\frac{1}{\sqrt{m}}\sum_{j=1}^{m}a_j\sigma(\langle w_j,x\rangle),\qquad x\in\mathbb{R}^d,$$

其中 $w_1,\dots,w_m$ 是 $\mathbb{R}^d$ 中独立同分布的随机向量，$a_1,\dots,a_m$ 独立同分布，均值为 0、方差为 σ_a^2，且与各 w_j 独立。这是初始化时宽度为 m 的单隐层网络，归一化使 $\operatorname{Var} f_m(x)$ 不随宽度增长而改变。

命题 1.24. 固定有限个输入 $x_1,\dots,x_k$，且对每个 i 假设 $\mathbb{E}[\sigma(\langle w,x_i\rangle)^2]<\infty$。则

$$(f_m(x_1),\dots,f_m(x_k))\Rightarrow\mathcal{N}(0,K),\qquad K(x,x')=\sigma_a^2\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)].$$

习题 1.25 (B 类)**.** 证明这一命题。令 $V_j=(a_j\sigma(\langle w_j,x_1\rangle),\dots,a_j\sigma(\langle w_j,x_k\rangle))\in\mathbb{R}^k$，并将 $(f_m(x_1),\dots,f_m(x_k))$ 识别为 $m^{-1/2}\sum_j V_j$。检验 $\mathbb{E}V_j=0$ 和 $\operatorname{Cov}(V_j)=K$，分别指出何处用到 a_j 与 w_j 的独立性。然后或者引用多维中心极限定理，或者对每个固定的 $v\in\mathbb{R}^k$ 将定理 1.7 应用于标量 $\langle v,V_j\rangle$，读出 $\mathbb{R}^k$ 上变换的收敛，并用引理 1.29 完成证明。说明两条路径中哪一条需要三阶矩。

习题 1.26 (A 类)**.** 证明对任意满足 $\mathbb{E}[\sigma(\langle w,x_i\rangle)^2]<\infty$ 的 σ，K 是合法的协方差，即对每个 $v\in\mathbb{R}^k$，$\sum_{i,l}v_iv_lK(x_i,x_l)\ge 0$。一行即可。

极限为高斯，无论 σ 及权重的分布是什么；它们只通过 K 起作用。

习题 1.27 (C 类)**.** 设 $\sigma=\max(\cdot,0)$，$w\sim\mathcal{N}(0,I_d)$。对非零的 x,x'，令 $\theta=\angle(x,x')$，证明

$$\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)]=\frac{\|x\|\,\|x'\|}{2\pi}\big(\sin\theta+(\pi-\theta)\cos\theta\big).$$

当 $\theta=0$ 时与 $\mathbb{E}[\max(0,g)^2]$ 核对；当 $\theta=\pi/2$ 时与独立性核对。这就是反余弦核。

注 1.28. 命题 1.24 涉及有限个输入。对 $\mathbb{R}^d$ 的每个有限子集都同时成立，正是称该极限为核 K 的高斯过程的含义——见第 9 讲。对数据作条件化就是第 1–2 讲的定理 2.9，其中 Σ 换为核矩阵；因此，以精确贝叶斯推断拟合的无限宽网络是核为 K 的核回归。有限宽度时 f_m 不是高斯的，差异大小是关于命题 1.24 收敛速率的问题，第 4 讲将给出答案。

译注： 原文有限宽度非高斯的说法描述一般随机隐特征情形，并非所有允许模型。若 $w_j\equiv w_0$ 为确定值，且各 a_j 为独立高斯，则任意有限个输入的输出在每个有限 m 已联合高斯（ReLU 也如此）。上面的过程极限仍按有限维分布理解。

1.9 * 我们没有给出的证明

本节不在课堂讲授。特征函数将和变成积，而 n 个近乎相等的因子之积是指数函数。这是定理 1.7 较早的证明。

引理 1.29 (连续性定理)**.** 设 Y_n,Y 为 $\mathbb{R}^k$ 中的随机向量，对每个 $t\in\mathbb{R}^k$ 都有 $\varphi_{Y_n}(t)\to\varphi_Y(t)$。则 $Y_n\Rightarrow Y$。

证明. 设 f 连续且 $f,\widehat{f}$ 均属于 $L^1(\mathbb{R}^k)$；作为可积函数的逆变换，f 有界。由傅里叶反演与 Fubini 定理（因 $\widehat{f}\in L^1$ 而可用），

$$\mathbb{E}f(Y_n)=\frac{1}{(2\pi)^k}\int_{\mathbb{R}^k}\widehat{f}(\xi)\mathbb{E}[e^{i\langle\xi,Y_n\rangle}]\,d\xi=\frac{1}{(2\pi)^k}\int_{\mathbb{R}^k}\widehat{f}(\xi)\varphi_{Y_n}(-\xi)\,d\xi.$$

由于 $|\varphi_{Y_n}| \le 1$ 且 $\widehat{f} \in L^1$，控制收敛给出

$$\mathbb{E} f(Y_n) \longrightarrow \frac{1}{(2\pi)^k} \int_{\mathbb{R}^k} \widehat{f}(\xi)\varphi_Y(-\xi)\,d\xi = \mathbb{E} f(Y).$$

习题 1.3 中使用的函数均属于此类：光滑截断函数 χ_M 紧支撑，因此 $\widehat{\chi}_M$ 是 Schwartz 函数；而 $g_\delta = g * \varphi_\delta$ 可积，其 $\widehat{g}_\delta = \widehat{g}\,\widehat{\varphi}_\delta$ 为有界函数与高斯函数之积。故该论证可原样使用并得到 $Y_n \Rightarrow Y$。（第 1–2 讲引入的结果均在 $\mathbb{R}^k$ 上成立。） □

习题 1.30 (A 类)**.** 对 $\mathbb{E}|X|^k < \infty$ 的情形，在期望内求 k 次导数——给出控制变量——得到 $\varphi_X^{(k)}(0) = (-i)^k \mathbb{E}[X^k]$。通过计算 $\varphi''(0)$ 和 $\varphi^{(4)}(0)$，与 $\varphi(t) = e^{-t^2/2}$ 核对，求回 $\mathbb{E}g^2 = 1$ 和 $\mathbb{E}g^4 = 3$。

引理 1.31. 若 $\mathbb{E}X = 0$ 且 $\mathbb{E}X^2 = 1$，则 $\varphi_X(t) = 1 - t^2/2 + r(t)$，其中 $r(t)/t^2 \to 0$。

证明. 对实数 θ，$|e^{i\theta} - 1 - i\theta + \theta^2/2| \le \min(|\theta|^3/6, \theta^2)$：第一个界来自积分形式的 Taylor 余项，第二个由 $|e^{i\theta} - 1 - i\theta| \le \theta^2/2$ 得到。取 $\theta = -tX$ 并取期望，利用 $\mathbb{E}X = 0$ 和 $\mathbb{E}X^2 = 1$，

$$|r(t)| \le \mathbb{E}\min\left(\frac{|t|^3|X|^3}{6}, t^2X^2 \right).$$

除以 t^2。被积函数受可积的 X^2 控制并逐点趋于 0，故控制收敛给出 $r(t)/t^2 \to 0$。最小值的第二个分支在无需三阶矩时提供控制变量。 □

习题 1.32 (B 类)**.** 证明当复数 $z_n \to z$ 时 $(1 + z_n/n)^n \to e^z$（若 $|a|, |b| \le M$，则 $|a^n - b^n| \le nM^{n-1}|a - b|$；取 $b = e^{z_n/n}$）。结合引理 1.31 得到 $\varphi_{S_n}(t) = [\varphi_{X_1}(t/\sqrt{n})]^n \to e^{-t^2/2}$，并推得 $S_n \Rightarrow \mathcal{N}(0,1)$。指出何处使用独立性，何处使用同分布。

习题 1.33 (A 类)**.** 设 $B \sim \mathrm{Bernoulli}(p)$，证明 $\varphi_B(t) = 1 + p(e^{-it} - 1)$。对独立的 $B_{n,i} \sim \mathrm{Bernoulli}(\lambda/n)$，令 $N_n = \sum_i B_{n,i}$，证明 $\varphi_{N_n}(t) \to \exp[\lambda(e^{-it} - 1)]$，并通过级数求和将极限辨认为 $\mathrm{Poisson}(\lambda)$。与习题 1.32 是相同的三行计算，只有归一化不同。

习题 1.34 (B 类)**.** 对中心化阵列 $X_{n,i} = B_{n,i} - \lambda/n$，证明 $s_n^2 = \lambda(1 - \lambda/n)$，且对每个 $\varepsilon < 1/\sqrt{\lambda}$ 都有 $L_n(\varepsilon) \to 1$，所以定义 1.8 不成立。取 $\lambda = 3$、$n = 10, 100, 10^4$ 精确计算 $L_n(1/2)$；应得到 0、0.970、1.000，且第一个应恰好为 0——说明原因。

习题 1.35 (C 类)**.** 取 $X_{n,i} = \pm 1$（$i \le n$）及另一个求和项 $X_{n,n+1} = \pm\sqrt{n}$，全部独立且对称。证明 $s_n^2 = 2n$，对 $\varepsilon < 1/\sqrt{2}$ 有 $L_n(\varepsilon) \ge 1/2$，且 $s_n^{-1}\sum_i X_{n,i}$ 的极限特征函数为 $e^{-t^2/4}\cos(t/\sqrt{2})$。给出使其为零的 t，并由此得出 $s_n^{-1}\sum_i X_{n,i}$ 不依分布收敛到任何高斯分布。Feller 条件在此也不成立，故注 1.10(c) 不适用，必须计算变换。无需事先知道极限存在，为什么一个零点就足够?

习题 1.36 (C 类)**.** 证明对 $X_i = \pm 1$，当 $\alpha > 1/2$ 时，不可能有 $\sup_z |\mathbb{P}(S_n \le z) - \Phi(z)| \le Cn^{-\alpha}$ 这样的界。当 n 为偶数时，$\mathbb{P}(S_n = 0) = \binom{n}{n/2} 2^{-n}$，由 Stirling 公式其渐近值为 $\sqrt{2/(\pi n)}$；现比较 $z = 0$ 附近的 $\mathbb{P}(S_n \le z)$ 与 $\Phi(z)$。用一句话解释为什么格点型求和项是第 1.6 节表中最慢的一行。

习题 1.37 (C 类)**.** 证明对任意实随机变量 Y 和任意 $u>0$，

$$\mathbb{P}(|Y|\geq 2/u)\leq \frac{1}{u}\int_{-u}^{u}(1-\varphi_Y(t))\,dt.$$

推得若 $\varphi_{Y_n}\to\psi$ 逐点成立且 ψ 在 0 处连续，则当 $K\to\infty$ 时 $\sup_n \mathbb{P}(|Y_n|>K)\to 0$。这是连续性定理中无需预先知道极限分布的一半。另一半——ψ 因而是某个随机变量的变换——是我们不需要的紧致性论证，因为引理 1.29 每次应用时极限已知。

> **第 3 讲指定作业，第 4 讲开始时交：** 习题 1.3、1.13、1.14、1.21、1.22、1.25、1.32、1.35——两道 A 类、三道 B 类、三道 C 类。第 1 节其余习题均属题库：供选做、属于考试范围，但无需上交。时间不足时请做 C 类题。

2 Stein 方法

定理 1.7 将高斯分布描述为极限。它还可以用一个恒等式来刻画。

> **问题：** 是否存在一个标准高斯分布满足而其他分布均不满足的恒等式？若存在，那么证明一个分布近似高斯，就转化为证明它近似满足该恒等式。

2.1 刻画

定理 2.1 (Stein 引理)**.** 随机变量 W 服从标准高斯分布，当且仅当对每个有界且导数有界的 $f\in C^1(\mathbb{R})$，

$$\mathbb{E}[Wf(W)]=\mathbb{E}[f'(W)].$$

正向证明. 令 $\varphi(x)=(2\pi)^{-1/2}e^{-x^2/2}$，则 $\varphi'(x)=-x\varphi(x)$。因此

$$\mathbb{E}[f'(g)]=\int f'\varphi=-\int f\varphi'=\int xf(x)\varphi(x)\,dx=\mathbb{E}[gf(g)].$$

□

反向在第 2.2 节证明。

注 2.2 (指数检验函数)**.** 取 $f(x)=e^{-itx}$，Stein 恒等式变成

$$\mathbb{E}[We^{-itW}]=-it\mathbb{E}[e^{-itW}],$$

即 $\varphi'(t)=-t\varphi(t)$，这是第 1–2 讲引理 1.10 的微分方程。分离一个求和项并作 Taylor 展开以得到 $\varphi'_{S_n}\approx -t\varphi_{S_n}$，即可证明中心极限定理；这条路径见第 1.9* 节。

习题 2.3 (B 类)**.** 向量形式。设 $X\sim\mathcal{N}(0,\Sigma)$ 取值于 $\mathbb{R}^d$，其中 $\Sigma\succeq 0$ 可以奇异；设 $f:\mathbb{R}^d\to\mathbb{R}$ 满足 $\widehat{f}$ 和 $|\xi|\widehat{f}(\xi)$ 可积，傅里叶变换及反演公式遵循第 1–2 讲命题 1.1。

(a) 证明

$$\mathbb{E}[X_j f(X)] = \sum_k \Sigma_{jk}\mathbb{E}[\partial_k f(X)], \qquad \text{即} \quad \mathbb{E}[Xf(X)] = \Sigma\mathbb{E}[\nabla f(X)].$$

关于变换的两个事实：乘以 X_j 作用在 $\xi \mapsto \mathbb{E}[e^{i\langle X,\xi\rangle}]$ 上相当于 $-i\partial_{\xi_j}$，而由第 1–2 讲定义 1.3，该函数为 $e^{-\xi^\top\Sigma\xi/2}$，故

$$\mathbb{E}[X_j e^{i\langle X,\xi\rangle}] = i(\Sigma\xi)_j e^{-\xi^\top\Sigma\xi/2};$$

并且 $\widehat{\partial_k f}(\xi) = i\xi_k\widehat{f}(\xi)$。用傅里叶反演写出所求恒等式两侧并比较被积函数。$\widehat{f} \in L^1(\mathbb{R}^d)$ 且 $\mathbb{E}|X_j| < \infty$ 保证 Fubini 定理可用；$\xi_k\widehat{f} \in L^1$ 则保证可通过反演恢复 $\partial_k f$。任何地方都没有用到 Σ 的非退化性。

(b) 反过来证明，若对每个有界且导数有界的 $F \in C^1(\mathbb{R}^d;\mathbb{R}^d)$，有

$$\mathbb{E}[\langle W, F(W)\rangle] = \mathbb{E}[\operatorname{tr}(\Sigma DF(W))],$$

则 $W \sim \mathcal{N}(0,\Sigma)$。取 $F(x) = vf(\langle v,x\rangle)$，化为对 $\langle v,W\rangle$ 应用定理 2.1，再用第 1–2 讲推论 1.7 完成证明。单独处理 $v^\top\Sigma v = 0$ 的情形。

(c) 矩阵形式。设随机矩阵 M 的元素联合高斯且均值为 0，F 在 $\mathbb{R}^{n\times m}$ 上满足上面的假设。证明

$$\mathbb{E}[M_{ij}F(M)] = \sum_{k,l}\mathbb{E}[M_{ij}M_{kl}]\,\mathbb{E}\left[\frac{\partial F}{\partial M_{kl}}(M)\right].$$

由 (a) 一行可得：矩阵是索引为一对指标的向量，其协方差 $\Sigma_{(ij),(kl)} = \mathbb{E}[M_{ij}M_{kl}]$，而 (a) 的证明完全没有使用索引集的形状。

2.2 Stein 方程

定理 2.1 表明，$W \sim \mathcal{N}(0,1)$ 恰当且仅当对每个容许的 f，

$$\mathbb{E}[f'(W) - Wf(W)] = 0.$$

我们需要它的定量形式：对给定的检验函数 h，给出 $\mathbb{E}h(W) - \mathbb{E}h(g)$ 的界。

假设对这个 h 能构造函数 f，使对每个 $w \in \mathbb{R}$ 都有 $f'(w) - wf(w) = h(w) - \mathbb{E}h(g)$。两边都是实变量函数，而 g 仅通过常数 $\mathbb{E}h(g)$ 进入；因此可将 $w = W$ 代入该恒等式并取平均，得到

$$\mathbb{E}h(W) - \mathbb{E}h(g) = \mathbb{E}[f'(W) - Wf(W)].$$

因此整个问题就是从 h 构造 f。固定 h，寻找满足下式的 f：

$$f'(w) - wf(w) = h(w) - \mathbb{E}h(g). \tag{3}$$

在第 2.2、2.3 节中，始终取 $h \in C^3(\mathbb{R})$，且 h', h'', h''' 有界；这是引理 1.2 中的函数类。对 $s \geq 0$，令

$$(T_s h)(w) = \mathbb{E}\left[h\left(e^{-s}w + \sqrt{1-e^{-2s}}\,g\right)\right].$$

独立高斯变量的方差相加，且 $e^{-2t}(1-e^{-2s})+1-e^{-2t}=1-e^{-2(s+t)}$，故 $T_sT_t=T_{s+t}$：这是 Ornstein–Uhlenbeck 半群。它在 $T_0h=h$ 与 $T_sh\to\mathbb{E}h(g)$ 之间插值，生成元为

$$Lu=\lim_{s\downarrow 0}\frac{T_su-u}{s}=u''-wu',$$

见下方证明中的计算；且 $\partial_sT_s=LT_s$。

现在由两个观察构造 f_h。记 $\widetilde{h}=h-\mathbb{E}h(g)$，则 $T_s\widetilde{h}=T_sh-\mathbb{E}h(g)\to 0$。第一，对 s 作望远镜积分，

$$\widetilde{h}=T_0\widetilde{h}-\lim_{s\to\infty}T_s\widetilde{h}=-\int_0^\infty\partial_sT_s\widetilde{h}\,ds=-L\int_0^\infty T_s\widetilde{h}\,ds.$$

第二，Stein 算子 $Af=f'-wf$ 是从 L 中提出一个导数而得：$A(u')=(u')'-wu'=Lu$。因此，取 $u=-\int_0^\infty T_s\widetilde{h}\,ds$ 并令 $f=u'$，就解得 $Af=\widetilde{h}$；即

$$f_h=-\int_0^\infty\partial_wT_sh\,ds,$$

常数 $\mathbb{E}h(g)$ 在 ∂_w 下消失。T_s 每对 w 求一次导数都会产生一个因子 e^{-s}，这使该积分收敛，并给出下面的界。

引理 2.4 (解及其导数)**.** 方程 (3) 恰有一个有界解，即

$$f_h=-\int_0^\infty\partial_wT_sh\,ds,\qquad f_h(w)=-\int_0^\infty e^{-s}\mathbb{E}\left[h'\left(e^{-s}w+\sqrt{1-e^{-2s}}\,g\right)\right]ds,$$

且它满足

$$\|f_h\|_\infty\le\|h'\|_\infty,\qquad\|f_h'\|_\infty\le\tfrac{1}{2}\|h''\|_\infty,\qquad\|f_h''\|_\infty\le\tfrac{1}{3}\|h'''\|_\infty.$$

特别地，$f_h\in C^2(\mathbb{R})$。

证明. 令 $b_s=\sqrt{1-e^{-2s}}$、$u(s,w)=(T_sh)(w)=\mathbb{E}[h(e^{-s}w+b_sg)]$，则 $u(0,w)=h(w)$，且当 $s\to\infty$ 时 $u(s,w)\to\mathbb{E}h(g)$。对 s 求导并使用 $\dot{b}_s=e^{-2s}/b_s$，

$$\begin{aligned}\partial_su&=\mathbb{E}\left[h'(e^{-s}w+b_sg)\left(-e^{-s}w+\frac{e^{-2s}}{b_s}g\right)\right]\\&=-e^{-s}w\mathbb{E}[h']+\frac{e^{-2s}}{b_s}\mathbb{E}[gh'].\end{aligned}$$

对 $g\mapsto h'(a+b_sg)$ 应用定理 2.1 得到 $\mathbb{E}[gh'(a+b_sg)]=b_s\mathbb{E}[h''(a+b_sg)]$，这也消除了 $s=0$ 处表面上的奇异性。由于 $\partial_wu=e^{-s}\mathbb{E}[h']$ 且 $\partial_w^2u=e^{-2s}\mathbb{E}[h'']$，上式恰好表示

$$\partial_su=\partial_w^2u-w\partial_wu.$$

现在 $f_h(w)=-\int_0^\infty\partial_wu(s,w)\,ds$ 即为所显示的公式，且

$$\begin{aligned}f_h'(w)-wf_h(w)&=-\int_0^\infty(\partial_w^2u-w\partial_wu)\,ds=-\int_0^\infty\partial_su\,ds\\&=u(0,w)-\lim_{s\to\infty}u(s,w)=h(w)-\mathbb{E}h(g),\end{aligned}$$

故 f_h 解式 (3)。两个解之差满足 $f' = wf$，因此形如 $ce^{w^2/2}$，仅当 $c = 0$ 时有界；而 f_h 有界，其上界为 $\|h'\|_\infty \int_0^\infty e^{-s} ds$。在积分内求导是合法的，因为第 k 个被积函数被 $e^{-ks}\|h^{(k)}\|_\infty$ 控制，由此得

$$f_h'(w) = -\int_0^\infty e^{-2s}\mathbb{E}[h''(e^{-s}w + b_s g)]\, ds,$$
$$f_h''(w) = -\int_0^\infty e^{-3s}\mathbb{E}[h'''(e^{-s}w + b_s g)]\, ds,$$

而 $\int_0^\infty e^{-ks} ds = 1/k$。 □

注 2.5. 将式 (3) 作为一阶线性方程求解，也可得到经典闭式

$$f_h(w) = e^{w^2/2} \int_{-\infty}^{w} [h(x) - \mathbb{E}h(g)] e^{-x^2/2}\, dx.$$

由唯一性，它是同一个函数。

取 $f = f_h$，上面的恒等式成为

$$\mathbb{E}h(W) - \mathbb{E}h(g) = \mathbb{E}[f_h'(W) - W f_h(W)]. \tag{4}$$

这就证明了定理 2.1 的反向。那里将检验函数限制为 C^1 不会损失一般性：式 (3) 的任何解都满足 $f' = wf + h - \mathbb{E}h(g)$，右侧连续，故每个解自动属于 C^1。由引理 2.4，f_h 就是这样的函数，它有界且导数有界，因而容许。所以若 W 满足该恒等式，式 (4) 右侧为零；于是对我们函数类中的每个 h，$\mathbb{E}h(W) = \mathbb{E}h(g)$，再由引理 1.2 和习题 1.3 得 $W \overset{d}{=} g$。

2.3 带速率的中心极限定理

定理 2.6. 设 $X_1, \dots, X_n$ 独立同分布，均值为 0、方差为 1，且 $\mathbb{E}|X_1|^3 < \infty$。则对每个导数有界的 $h \in C^3(\mathbb{R})$，

$$|\mathbb{E}h(S_n) - \mathbb{E}h(g)| \le \frac{\|h'''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}}.$$

证明. 记 $W = S_n$，令 $W^{(i)} = W - X_i/\sqrt{n}$，它与 X_i 独立，并简记 $f = f_h$。于是

$$\mathbb{E}[W f(W)] = \frac{1}{\sqrt{n}} \sum_i \mathbb{E}[X_i f(W)].$$

将 $f(W) = f(W^{(i)}) + \frac{X_i}{\sqrt{n}} f'(W^{(i)}) + R_i$ 作 Taylor 展开，余项满足 $|R_i| \le \frac{\|f''\|_\infty}{2} \frac{X_i^2}{n}$。对每个 i，

$$\mathbb{E}[X_i f(W)] = \underbrace{\mathbb{E}[X_i]}_{=0} \mathbb{E}[f(W^{(i)})] + \frac{1}{\sqrt{n}} \underbrace{\mathbb{E}[X_i^2]}_{=1} \mathbb{E}[f'(W^{(i)})] + \mathbb{E}[X_i R_i],$$

其中 $|\mathbb{E}[X_i R_i]| \le \|f''\|_\infty \mathbb{E}|X_1|^3/(2n)$，而前两项的期望可分解是因为 X_i 与 $W^{(i)}$ 独立。求和得

$$\left| \mathbb{E}[W f(W)] - \frac{1}{n} \sum_i \mathbb{E}[f'(W^{(i)})] \right| \le \frac{\|f''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}}.$$

每个 $\mathbb{E}[f'(W^{(i)})]$ 与 $\mathbb{E}[f'(W)]$ 之差的绝对值至多为 $\|f''\|_\infty \mathbb{E}|X_i|/\sqrt{n}$，因此

$$\begin{aligned}|\mathbb{E}[f'(W) - Wf(W)]| &\le \frac{\|f''\|_\infty}{\sqrt{n}} \left(\mathbb{E}|X_1| + \tfrac{1}{2}\mathbb{E}|X_1|^3\right) \\ &\le \frac{3\|f''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}},\end{aligned}$$

因为 $\mathbb{E}|X_1| \le (\mathbb{E}X_1^2)^{1/2} = 1 \le (\mathbb{E}X_1^2)^{3/2} \le \mathbb{E}|X_1|^3$。现在将引理 2.4 的 $\|f''\|_\infty \le \frac{1}{3}\|h'''\|_\infty$ 代入式 (4)。 □

注 2.7. 对同一函数类，定理 1.7 给出 $\frac{\|h'''\|_\infty}{6\sqrt{n}}(\mathbb{E}|X_1|^3 + 2\sqrt{2/\pi})$，所以两个界只差一个常数因子。

同样的论证配合不同的刻画恒等式，可给出全变差距离下带速率的 Poisson 极限定理（第 2.4 节），并且不需要独立性（第 2.5* 节）。

2.4 对 Poisson 分布使用同一论证

译注： 以下含 $1/\lambda$、π_k 分母的递推和界取 $\lambda > 0$。$\lambda = 0$ 是集中于 0 的退化分布；Le Cam 情形此时所有 $p_i = 0$，两分布相同、全变差为 0，无须使用这些除法。

上面的论证没有任何部分专属于高斯分布；用到的只是刻画恒等式。记 Poisson(λ) 的权重为 $\pi_k = e^{-\lambda}\lambda^k/k!$，$\pi(A) = \sum_{k\in A}\pi_k$；回忆在 $\{0,1,2,\ldots\}$ 上的分布之间，

$$d_{\mathrm{TV}}(X,Y) = \sup_{A\subseteq\{0,1,2,\ldots\}} |\mathbb{P}(X\in A) - \mathbb{P}(Y\in A)|.$$

定理 2.8 (Chen 引理)**.** 取值于 $\{0,1,2,\ldots\}$ 的随机变量 N 服从 Poisson(λ)，当且仅当对每个有界函数 $f:\{0,1,2,\ldots\}\to\mathbb{R}$，

$$\mathbb{E}[\lambda f(N+1) - Nf(N)] = 0.$$

正向证明.

$$\mathbb{E}[Nf(N)] = \sum_{k\ge1} ke^{-\lambda}\frac{\lambda^k}{k!}f(k) = \lambda\sum_{j\ge0} e^{-\lambda}\frac{\lambda^j}{j!}f(j+1) = \lambda\mathbb{E}[f(N+1)].$$

□

反向和定量陈述来自式 (3) 的类似物。固定 A，寻找满足下式的 f：

$$\lambda f(k+1) - kf(k) = \mathbf{1}_A(k) - \pi(A), \qquad k \ge 0. \tag{5}$$

此处差分算子代替导数，也没有需要积分的半群：式 (5) 是一阶递推，可以直接求解。

引理 2.9. 令 $f_A(0) = 0$。则式 (5) 有唯一解

$$f_A(k) = \frac{1}{k\pi_k}\sum_{j<k}\pi_j(\mathbf{1}_A(j) - \pi(A)) = -\frac{1}{k\pi_k}\sum_{j\ge k}\pi_j(\mathbf{1}_A(j) - \pi(A)), \qquad k \ge 1,$$

它有界，且

$$|(k-\lambda)f_A(k)| \le 1 \quad \text{对每个} k, \qquad \|\Delta f_A\|_\infty := \sup_k |f_A(k+1) - f_A(k)| \le \frac{2}{\lambda}.$$

证明. 记 $g = \mathbf{1}_A - \pi(A)$，则 $\sum_j \pi_j g(j) = 0$。将式 (5) 乘以 π_k 并利用 $\lambda\pi_k = (k+1)\pi_{k+1}$，得到

$$(k+1)\pi_{k+1} f(k+1) - k\pi_k f(k) = \pi_k g(k),$$

这是关于 $k \mapsto k\pi_k f(k)$ 的望远镜递推，在 $k = 0$ 时从 0 开始。求和给出第一个公式，第二个由 $\sum_j \pi_j g(j) = 0$ 得到。由于 $|g| \le 1$，对于 $N \sim \mathrm{Poisson}(\lambda)$，

$$|f_A(k)| \le \frac{1}{k\pi_k} \min\bigl(\mathbb{P}(N \le k-1), \mathbb{P}(N \ge k)\bigr). \tag{6}$$

当 $k > \lambda$ 时，比值 $\pi_{k+m}/\pi_k = \prod_{r=1}^{m} \lambda/(k+r)$ 至多为 $(\lambda/k)^m$，故 $\mathbb{P}(N \ge k) \le \pi_k k/(k-\lambda)$，由式 (6) 得 $|f_A(k)| \le 1/(k-\lambda)$。当 $1 \le k \le \lambda$ 时，比值 π_{k-1-m}/π_{k-1} 至多为 $((k-1)/\lambda)^m$，故 $\mathbb{P}(N \le k-1) \le \pi_{k-1}\lambda/(\lambda - k + 1)$；由 $\pi_{k-1} = k\pi_k/\lambda$ 和式 (6) 得 $|f_A(k)| \le 1/(\lambda - k + 1)$。两种情况下均有 $|(k-\lambda) f_A(k)| \le 1$，$k = 0$ 的情形显然。第一个界还说明 $f_A(k) \to 0$，所以 f_A 有界。

最后，将式 (5) 两边减去 $\lambda f(k)$，得到

$$\Delta f_A(k) = \frac{(k-\lambda) f_A(k) + g(k)}{\lambda},$$

分子的两项绝对值均至多为 1。 □

将 $k = W$ 代入式 (5) 并取期望，得到式 (4) 的类似物：

$$\mathbb{P}(W \in A) - \pi(A) = \mathbb{E}[\lambda f_A(W+1) - W f_A(W)]. \tag{7}$$

这证明了定理 2.8 的反向：若 W 满足恒等式，由于每个 f_A 有界，右侧对每个 A 都为零，故 $W \sim \mathrm{Poisson}(\lambda)$。

定理 2.10 (Le Cam)**.** 设 $B_1, \dots, B_n$ 独立，$B_i \sim \mathrm{Bernoulli}(p_i)$，令 $\lambda = \sum_i p_i$。则

$$d_{\mathrm{TV}}\left(\sum_i B_i, \mathrm{Poisson}(\lambda) \right) \le \frac{2}{\lambda} \sum_i p_i^2 \le 2 \max_i p_i.$$

证明. 令 $W = \sum_i B_i$、$W_i = W - B_i$，后者与 B_i 独立。固定 A 并记 $f = f_A$。因为 $B_i f(W) = B_i f(W_i + 1)$，

$$\mathbb{E}[W f(W)] = \sum_i \mathbb{E}[B_i f(W_i + 1)] = \sum_i p_i \mathbb{E}[f(W_i + 1)],$$

而 $\lambda = \sum_i p_i$ 给出 $\mathbb{E}[\lambda f(W+1)] = \sum_i p_i \mathbb{E}[f(W_i + B_i + 1)]$。相减得

$$\mathbb{E}[\lambda f(W+1) - W f(W)] = \sum_i p_i \mathbb{E}[f(W_i + B_i + 1) - f(W_i + 1)].$$

当 $B_i = 0$ 时方括号为零，当 $B_i = 1$ 时等于 $\Delta f(W_i + 1)$；由于 B_i 与 W_i 独立，第 i 项为 $p_i^2 \mathbb{E}[\Delta f(W_i + 1)]$。故由式 (7) 和引理 2.9，

$$|\mathbb{P}(W \in A) - \pi(A)| \le \|\Delta f_A\|_\infty \sum_i p_i^2 \le \frac{2}{\lambda} \sum_i p_i^2,$$

该界对 A 一致成立。定理中的第二个不等式来自 $\sum_i p_i^2 \le (\max_i p_i) \sum_i p_i$。 □

推论 2.11 (Poisson 极限定理)**.** 设 $B_{n,i} \sim \mathrm{Bernoulli}(p_{n,i})$ $(i \le k_n)$ 独立，且 $\max_i p_{n,i} \to 0$、$\sum_i p_{n,i} \to \lambda > 0$。则 $\sum_i B_{n,i} \Rightarrow \mathrm{Poisson}(\lambda)$。

证明. 界 $2\max_i p_{n,i}$ 趋于 0，且当 $\lambda_n \to \lambda$ 时 $\mathrm{Poisson}(\lambda_n) \Rightarrow \mathrm{Poisson}(\lambda)$。 □

这是第 1.6 节边界的 Poisson 一侧，且与定理 2.6 不同，它是全变差距离下的界。取 $p_i = \lambda/n$，该界为 $2\lambda/n$；当 $\lambda = 3$、$n = 100$ 时为 0.06，而真实全变差距离为 0.0076。引理 2.9 中常数 2 可改进为 $1 - e^{-\lambda}$，且可取到。

同一技巧覆盖第 1.6 节边界的两侧；改变的只是刻画恒等式。

2.5 * 独立性用在何处

本节不在课堂讲授。定理 2.6 的证明恰在一处使用独立性，以计算

$$\mathbb{E}[X_i f(W^{(i)})] = \mathbb{E}[X_i]\mathbb{E}[f(W^{(i)})].$$

任何其他计算该期望的途径都可以，最廉价的是耦合。

定义 2.12 (可交换对)**.** 若 $(W, W') \overset{d}{=} (W', W)$，则称 (W, W') 可交换。若还对某个 $a > 0$ 满足 $\mathbb{E}[W' - W \mid W] = -aW$，则称其为 Stein 对。

习题 2.13 (A 类)**.** 设 (W, W') 可交换，F 反对称，即 $F(x, y) = -F(y, x)$，且 $\mathbb{E}|F(W, W')| < \infty$。证明 $\mathbb{E}F(W, W') = 0$。一行即可；其余工作全在于选择 F。

习题 2.14 (B 类)**.** 对 $F(x, y) = (y - x)(f(x) + f(y))$ 应用上述结论，将 $f(W')$ 在 W 处展开到一阶，并利用定义 2.12 得到

$$\mathbb{E}[f'(W) - Wf(W)] = \mathbb{E}\left[f'(W)\left(1 - \frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid W]\right)\right] + \mathrm{err},$$
$$|\mathrm{err}| \le \frac{\|f''\|_\infty}{4a}\mathbb{E}|W' - W|^3.$$

高斯近似现要求两件事：$\frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid W]$ 接近 1，以及 $W' - W$ 小。

习题 2.15 (B 类)**.** 标准构造的对。取 $W = S_n$，令 I 在 $\{1, \dots, n\}$ 上均匀，X_I' 是独立的 X_I 副本；令 $W' = W - (X_I - X_I')/\sqrt{n}$。证明 (W, W') 可交换且 $\mathbb{E}[W' - W \mid X_1, \dots, X_n] = -W/n$，故 $a = 1/n$；然后证明

$$\mathbb{E}[(W' - W)^2 \mid X_1, \dots, X_n] = n^{-2}\sum_i (X_i^2 + 1),$$
$$\frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid X_1, \dots, X_n] = \tfrac{1}{2}\left(1 + \frac{1}{n}\sum_i X_i^2\right),$$

后者与 1 的 L^2 距离为 $\frac{1}{2}\sqrt{\mathrm{Var}(X_1^2)/n}$。再假设 $\mathbb{E}X_1^4 < \infty$，推得与定理 2.6 同量级的界。独立性进入两次——通过重新采样的副本，以及通过 $\frac{1}{n}\sum_i X_i^2$ 的方差——但两处都不是第 2.3 节中的乘积公式。

下面是一个任何形式的独立性都不适用的和。设 π 是 $\{1, \dots, n\}$ 上的均匀随机置换，令 $I_i = \mathbf{1}\{\pi(i) = i\}$，$W = \sum_i I_i$ 计数不动点。

习题 2.16 (A 类)**.** 证明当 $n \geq 2$ 时 $\mathbb{E}W = \operatorname{Var} W = 1$，并证明 $\mathbb{P}(I_1 = I_2 = 1) \neq \mathbb{P}(I_1 = 1)\mathbb{P}(I_2 = 1)$。一名学生取 $p_i = 1/n$、$\lambda = 1$，应用定理 2.10 得出 $d_{\mathrm{TV}}(W, \mathrm{Poisson}(1)) \leq 2/n$。指出哪个假设不成立，并说明为何结论碰巧正确也不能挽救该论证。

引入的结果：耦合形式的 Chen–Stein

令 $W = \sum_{i \leq n} I_i$，其中 $I_i \sim \mathrm{Bernoulli}(p_i)$，不一定相互独立，$\lambda = \sum_i p_i$。若对每个 i 都能在与 W 相同的概率空间上构造变量 V_i，使其分布等于给定 $I_i = 1$ 时 $W - 1$ 的分布，则

$$d_{\mathrm{TV}}(W, \mathrm{Poisson}(\lambda)) \leq \min(1, \lambda^{-1}) \sum_i p_i \mathbb{E}|W - V_i|.$$

习题 2.17 (C 类)**.** 构造耦合。固定 i；若 $\pi(i) = i$ 则令 $\sigma = \pi$，否则令 $\sigma = \pi \circ (i\ \pi^{-1}(i))$。证明始终有 $\sigma(i) = i$，σ 在固定 i 的置换中均匀，并且当 $\pi(i) \neq i$ 时 $W(\sigma) - W(\pi) \in \{1, 2\}$——当且仅当 π 在 i 处有一个二循环时取值 2。推得 $\mathbb{E}|W - V_i| \leq 2/n$，因而 $d_{\mathrm{TV}}(W, \mathrm{Poisson}(1)) \leq 2/n$。

容斥原理给出 $\mathbb{P}(W = 0) = \sum_{k \leq n} (-1)^k / k!$；当 $n = 4, 6, 10$ 时，其与 e^{-1} 的距离分别为 7.1×10^{-3}、1.8×10^{-4} 和 2.3×10^{-8}。当 $n = 10$ 时，此方法的误差相差多少个数量级？它具有什么容斥原理所没有的优点？

第 1.8* 节推导宽网络极限并计算反余弦核；第 1.9* 节给出中心极限定理的特征函数证明、Poisson 情形的同类计算，以及边界两侧的 Lindeberg 条件；第 2.5* 节推导可交换对的界及完全没有独立性的情形。

第 4 讲指定作业，第 5 讲开始时交：习题 2.13–2.17——两道 A 类、两道 B 类、一道 C 类。习题 2.3 属于题库。时间不足时请做 C 类题。