

# 现代机器学习中的概率

## ORF 526 课程材料译稿

第 12–15 讲：鞅（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

# 1 回顾：$L^2$、投影与条件期望

**第 12–15 讲：鞅**

条件期望 · 停时与收敛 · 鞅中心极限定理 · 集中性

**阅读指南**。第 1 节回顾 $L^2$ 和正交投影，并定义条件期望。第 1–2 节是第 12 讲，第 3 节是第 13 讲，第 4 节是第 14 讲，第 5 节是第 15 讲。所有内容均在 $L^2$ 中进行。来自课程外的事实放在标记为“引用”的方框中。标记为“课堂演算”的例子将在黑板上完成。习题分 A 类（常规）、B 类（演算例子或短证明）和 C 类（较长；鼓励使用 AI 辅助）；一讲的家庭作业是其结尾的习题组。

**译注：** 原文“所有内容均在 $L^2$”需作范围补充。$X \in L^2$ 的平方、残差平方一般仅在 $L^1$，可积三次余项也未必在 $L^2$。下文条件方差、平方鞅 / 次鞅、最大不等式的平方过程及条件 Taylor 余项，须使用条件期望对 $L^1$ 的标准延拓（由可积性和对有界条件检验函数的积分恒等式刻画），不能仅诉诸已写的 $L^2$ 正交投影。平方过程是可积鞅 / 次鞅，未必为原定义的 $L^2$ 鞅；若坚持后者就需相应四阶或更高矩。各 $L^2$ 收敛 / 正交结论仍使用其明确二阶矩条件。

## 1.1 $L^2$ 与正交投影

$L^2$ 是满足 $\mathbb{E}X^2 < \infty$ 的实随机变量 $X$ 所组成的空间，内积和范数为

$$\langle X, Z\rangle = \mathbb{E}[XZ], \qquad \|X\|_2 = (\mathbb{E}X^2)^{1/2}.$$

对有限随机变量族 $Y = (Y_1, \dots, Y_n)$（取值于某个 $\mathbb{R}^m$），令

$$L^2(Y) = \{f(Y) : f : \mathbb{R}^m \to \mathbb{R},\ \mathbb{E}f(Y)^2 < \infty\},$$

即 $Y$ 的具有有限二阶矩的函数。它是 $L^2$ 的线性子空间，包含常数；对任意其他随机变量族 $Y'$，都有 $L^2(Y) \subset L^2(Y, Y')$。

引用 · Hilbert 空间

$L^2$ 完备：在 $\|\cdot\|_2$ 下为 Cauchy 的序列在该范数下收敛。每个 $L^2(Y)$ 均为闭子空间。对闭子空间 $V \subset L^2$ 和 $X \in L^2$，存在唯一的 $P_V X \in V$ 使 $\|X - P_V X\|_2 = \min_{W \in V} \|X - W\|_2$，其特征为对所有 $W \in V$，$\langle X - P_V X, W\rangle = 0$。映射 $P_V$ 线性，且 $\|P_V X\|_2 \le \|X\|_2$；$\|X\|_2^2 = \|P_V X\|_2^2 + \|X - P_V X\|_2^2$；若 $V \subset W$ 为闭子空间，则 $P_V P_W = P_W P_V = P_V$。

## 1.2 条件期望

**定义 1.1** (条件期望)**.** 对 $X \in L^2$ 和有限随机变量族 $Y$，定义 $\mathbb{E}[X \mid Y] := P_{L^2(Y)} X$，即 $X$ 到 $L^2(Y)$ 的正交投影。

这是第 1–2 讲的定义：$\mathbb{E}[X \mid Y]$ 在所有满足 $f(Y) \in L^2$ 的函数 $f$ 中使 $\mathbb{E}(X - f(Y))^2$ 最小，即通过任意 $Y$ 的函数对 $X$ 作最佳均方预测。最佳线性预测则是到较小子空间 $\operatorname{span}(1, Y_1, \dots, Y_n)$ 的投影；两者一般不同（例 1.7），对高斯向量则相同（定理 1.6）。

**引理 1.2** (刻画)**.** 设 $Z \in L^2(Y)$。则 $Z = \mathbb{E}[X \mid Y]$ 当且仅当对每个 $f(Y) \in L^2(Y)$ 都有 $\mathbb{E}[(X-Z)f(Y)] = 0$；只检验有界 $f$ 就足够。

证明. 第一条即方框中的刻画。对于第二条，作截断：$f_M = \max(-M, \min(f, M))$ 满足 $f_M(Y) \to f(Y)$ 于 $L^2$ 中，且由 Cauchy–Schwarz，$\mathbb{E}[(X-Z)f_M(Y)] \to \mathbb{E}[(X-Z)f(Y)]$。 □

**命题 1.3** (规则)**.** 设 $X, X' \in L^2$，$a, b \in \mathbb{R}$，$Y, Y'$ 为有限随机变量族。

(i) 线性：$\mathbb{E}[aX + bX' \mid Y] = a\mathbb{E}[X \mid Y] + b\mathbb{E}[X' \mid Y]$。

(ii) 取平均：$\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}X$。

(iii) 提出已知量：若 $g(Y) \in L^2(Y)$ 且 $g(Y)X \in L^2$，则 $g(Y)\mathbb{E}[X \mid Y] \in L^2$，且 $\mathbb{E}[g(Y)X \mid Y] = g(Y)\mathbb{E}[X \mid Y]$；特别地，$\mathbb{E}[g(Y) \mid Y] = g(Y)$。

(iv) 塔式性质：$\mathbb{E}[\mathbb{E}[X \mid Y, Y'] \mid Y] = \mathbb{E}[X \mid Y] = \mathbb{E}[\mathbb{E}[X \mid Y] \mid Y, Y']$。

(v) 独立性：若 $X$ 与 $Y$ 独立，则 $\mathbb{E}[X \mid Y] = \mathbb{E}X$。

(vi) 非负性：若 $X \geq 0$，则 $\mathbb{E}[X \mid Y] \geq 0$；因此 $X \leq X'$ 蕴含 $\mathbb{E}[X \mid Y] \leq \mathbb{E}[X' \mid Y]$，且 $|\mathbb{E}[X \mid Y]| \leq \mathbb{E}[|X| \mid Y]$。

(vii) 勾股恒等式：$\mathbb{E}X^2 = \mathbb{E}(\mathbb{E}[X \mid Y])^2 + \mathbb{E}(X - \mathbb{E}[X \mid Y])^2$。

(viii) 收缩性：$\mathbb{E}(\mathbb{E}[X \mid Y])^2 \leq \mathbb{E}X^2$，且 $\mathbb{E}(\mathbb{E}[X \mid Y] - \mathbb{E}[X' \mid Y])^2 \leq \mathbb{E}(X - X')^2$。

证明. (i)、(iv)、(vii)、(viii) 是方框中列出的正交投影性质；(iv) 使用 $L^2(Y) \subset L^2(Y, Y')$。记 $Z = \mathbb{E}[X \mid Y]$ 并使用引理 1.2。(ii) 对 $f \equiv 1$ 检验。(iii) 对有界 $g$，$g(Y)Z \in L^2(Y)$，且对有界 $f$ 有 $\mathbb{E}[(g(Y)X - g(Y)Z)f(Y)] = \mathbb{E}[(X-Z)(gf)(Y)] = 0$。对一般 $g$ 作截断 $g_M = \max(-M, \min(g, M))$。则 $g_M(Y)X \to g(Y)X$ 于 $L^2$，故由 (viii)，$\mathbb{E}[g_M(Y)X \mid Y] \to \mathbb{E}[g(Y)X \mid Y]$ 于 $L^2$；而 $\mathbb{E}[g_M(Y)X \mid Y] = g_M(Y)Z$，且对每个 $M$，$\|g_M(Y)Z\|_2 \leq \|g_M(Y)X\|_2 \leq \|g(Y)X\|_2$，因此令 $M \to \infty$，得到 $g(Y)Z \in L^2$ 且 $g_M(Y)Z \to g(Y)Z$ 于 $L^2$。两极限相同。(v) $\mathbb{E}[(X - \mathbb{E}X)f(Y)] = \mathbb{E}[X - \mathbb{E}X]\mathbb{E}f(Y) = 0$。(vi) 对 $f(Y) = \mathbf{1}_{\{Z<0\}}$ 检验：$\mathbb{E}[Z\mathbf{1}_{\{Z<0\}}] = \mathbb{E}[X\mathbf{1}_{\{Z<0\}}] \geq 0$，故 $\mathbb{P}(Z < 0) = 0$；其余结论将线性分别用于 $X' - X \geq 0$ 和 $\pm X \leq |X|$ 即得。 □

**定义 1.4** (条件方差)**.** $\operatorname{Var}(X \mid Y) := \mathbb{E}[(X - \mathbb{E}[X \mid Y])^2 \mid Y]$。由 (ii)、(vii)，$\operatorname{Var} X = \mathbb{E}\operatorname{Var}(X \mid Y) + \operatorname{Var}(\mathbb{E}[X \mid Y])$。

**引理 1.5** (冻结)**.** 设 $U \in L^2(Y)$ 取值于 $\mathbb{R}^p$，随机变量 $Z$ 取值于 $\mathbb{R}^q$ 且与 $Y$ 独立，$h : \mathbb{R}^p \times \mathbb{R}^q \to \mathbb{R}$ 满足 $h(U, Z) \in L^2$。令 $\overline{h}(u) = \mathbb{E}h(u, Z)$，则 $\mathbb{E}[h(U, Z) \mid Y] = \overline{h}(U)$。

证明. $\overline{h}(U) \in L^2(Y)$。对有界 $f$，由于 $Z$ 与 $(U, Y)$ 独立，可先对 $Z$ 积分：$\mathbb{E}[h(U, Z)f(Y)] = \mathbb{E}[\overline{h}(U)f(Y)]$。应用引理 1.2。 □

**定理 1.6** (高斯条件化，第 1–2 讲)**.** 设 $(X, Y)$ 在 $\mathbb{R}^p \times \mathbb{R}^m$ 中联合高斯，$\Sigma_{YY}$ 可逆，令 $A = \Sigma_{XY}\Sigma_{YY}^{-1}$。则 $X - AY$ 与 $Y$ 独立，且

$$\mathbb{E}[X \mid Y] = \mu_X + A(Y - \mu_Y), \qquad \operatorname{Var}(X \mid Y) = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}.$$

第一个恒等式逐坐标理解；第二个是条件协方差矩阵，不依赖于 $Y$。也就是说，对联合高斯的 $(X,Y)$，所有 $Y$ 的函数中最佳预测是线性的，且给定 $Y$ 时 $X$ 的条件分布为具有所显示均值和协方差的高斯分布。

**例 1.7** (非高斯二元组)**.** 设 $Y$ 在 $[-1,1]$ 上均匀，$X=Y^2$（第 2 讲的失效情形）。则 $\operatorname{Cov}(X,Y)=\mathbb{E}Y^3=0$，所以由 $Y$ 预测 $X$ 的最佳线性预测是常数 $\mathbb{E}X=1/3$，残差方差为 $\operatorname{Var}Y^2=4/45$；而由规则 (iii)，$\mathbb{E}[X\mid Y]=Y^2$，残差为零。

# 2 鞅

## 2.1 滤过

固定随机变量序列 $Y_1,Y_2,\dots$（每个取值于某个 $\mathbb{R}^m$）。对 $n\ge 0$ 定义

$$\mathbb{E}[X\mid\mathcal{F}_n]:=\mathbb{E}[X\mid Y_1,\dots,Y_n],\qquad\qquad L^2(\mathcal{F}_n):=L^2(Y_1,\dots,Y_n),$$

并令 $\mathbb{E}[X\mid\mathcal{F}_0]:=\mathbb{E}X$、$L^2(\mathcal{F}_0)$ 为常数空间。简记 $\mathbb{E}_n[X]:=\mathbb{E}[X\mid\mathcal{F}_n]$。符号 $\mathcal{F}_n$ 表示 “前 $n$ 个变量”；序列 $(\mathcal{F}_n)_{n\ge0}$ 是由 $(Y_n)$ 生成的滤过。由塔式法则，

$$\mathbb{E}_m\mathbb{E}_n=\mathbb{E}_n\mathbb{E}_m=\mathbb{E}_m\qquad(m\le n).$$

**定义 2.1.** 若对每个 $n$ 有 $X_n\in L^2(\mathcal{F}_n)$，称序列 $(X_n)_{n\ge0}$ 为适应的；若对每个 $n\ge1$ 有 $X_n\in L^2(\mathcal{F}_{n-1})$，称其为可预测的。

## 2.2 鞅与正交增量

**定义 2.2** (鞅)**.** 令 $(\mathcal{F}_n)$ 为序列 $(Y_n)$ 生成的滤过。$L^2$ 中的序列 $(M_n)_{n\ge0}$ 若适应且对所有 $n\ge0$ 满足 $\mathbb{E}_n[M_{n+1}]=M_n$，则称其为关于 $(\mathcal{F}_n)$ 的鞅；若适应且 $\mathbb{E}_n[M_{n+1}]\ge M_n$，称为次鞅；若适应且 $\mathbb{E}_n[M_{n+1}]\le M_n$，称为上鞅。$M$ 的差分为 $\xi_n=M_n-M_{n-1}$（$n\ge1$）；鞅性质写为 $\mathbb{E}_{n-1}[\xi_n]=0$。

滤过是给定数据的一部分。每个序列 $(M_n)$ 都生成自身的滤过（取 $Y_n=M_n$）；关于滤过 $(\mathcal{F}_n)$ 的鞅也是关于自身滤过的鞅（适应性给出 $L^2(M_0,\dots,M_n)\subset L^2(\mathcal{F}_n)$；再应用塔式法则），但反之不然。下文除非另作说明，“鞅” 均指关于第 2.1 节的滤过的鞅。

由塔式法则，当 $m\le n$ 时 $\mathbb{E}_m[M_n]=M_m$，且 $\mathbb{E}M_n=\mathbb{E}M_0$。反过来，若 $(\xi_n)_{n\ge1}$ 适应且 $\mathbb{E}_{n-1}\xi_n=0$，则对任意常数 $M_0$，$M_n=M_0+\sum_{k\le n}\xi_k$ 是鞅。

**引理 2.3** (正交增量)**.** 设 $M$ 为差分为 $\xi_k$ 的鞅。若 $W\in L^2(\mathcal{F}_{n-1})$，则 $\mathbb{E}[W\xi_n]=0$。因此当 $m\ne n$ 时 $\mathbb{E}[\xi_m\xi_n]=0$，且

$$\mathbb{E}M_n^2=\mathbb{E}M_0^2+\sum_{k=1}^{n}\mathbb{E}\xi_k^2,\qquad\qquad\mathbb{E}(M_n-M_m)^2=\sum_{k=m+1}^{n}\mathbb{E}\xi_k^2\qquad(m\le n).$$

*证明.* $\mathbb{E}_{n-1}\xi_n=0$ 表明 $\xi_n$ 到 $L^2(\mathcal{F}_{n-1})$ 的投影为 0，即 $\xi_n\perp L^2(\mathcal{F}_{n-1})$（引理 1.2 中取 $Z=0$）。由于 $M_0$ 和 $m<n$ 时的 $\xi_m$ 均属于 $L^2(\mathcal{F}_{n-1})$，$M_n=M_0+\xi_1+\cdots+\xi_n$ 的各项两两正交，所述恒等式即为勾股定理。 □

### 2.3 例子

**例 2.4.** (a) **独立变量之和。课堂演算。**设 $Y_1, Y_2, \dots$ 独立且中心化，方差为 $s_k^2 = \mathbb{E}Y_k^2$，令 $S_n = \sum_{k\le n} Y_k$。则

$$S_n, \qquad S_n^2 - \sum_{k\le n} s_k^2, \qquad \frac{e^{\lambda S_n}}{\prod_{k\le n}\mathbb{E}e^{\lambda Y_k}} \quad (\lambda\in\mathbb{R},\ \mathbb{E}e^{2\lambda Y_k}<\infty)$$

都是鞅。确实，由规则 (iii)、(v)，$\mathbb{E}_n S_{n+1} = S_n + \mathbb{E}Y_{n+1} = S_n$；$\mathbb{E}_n[S_{n+1}^2] = S_n^2 + 2S_n\mathbb{E}Y_{n+1} + \mathbb{E}Y_{n+1}^2 = S_n^2 + s_{n+1}^2$；且 $\mathbb{E}_n[e^{\lambda S_{n+1}}] = e^{\lambda S_n}\mathbb{E}e^{\lambda Y_{n+1}}$。对简单随机游走（$Y_k = \pm 1$ 各以概率 $1/2$ 取值），它们为 $S_n$、$S_n^2 - n$ 和 $e^{\lambda S_n}/(\cosh\lambda)^n$。

(b) **独立同分布情形的指数鞅。**若 $Y_k$ 独立同分布，$\psi(\lambda) = \log\mathbb{E}e^{\lambda Y_1}$，则 (a) 中第三个鞅为 $M_n = \exp(\lambda S_n - n\psi(\lambda))$。

(c) **Doob 鞅。**对 $f(Y_1,\dots,Y_N)\in L^2$，由塔式法则，序列 $M_n = \mathbb{E}_n[f(Y_1,\dots,Y_N)]$ $(0\le n\le N)$ 是鞅，且 $M_0 = \mathbb{E}f$、$M_N = f$。故 $f - \mathbb{E}f = \sum_{k=1}^N \xi_k$，并由引理 2.3，$\operatorname{Var} f = \sum_{k\le N}\mathbb{E}\xi_k^2$。

(d) **随机梯度下降。**设 $\ell(\theta; z)$ 为损失，$\theta\in\mathbb{R}^d$，总体损失 $L(\theta) = \mathbb{E}\ell(\theta; z)$，且假设对每个 $\theta$ 都有 $\mathbb{E}\|\nabla\ell(\theta; z)\|^2 < \infty$。设 $z_1, z_2, \dots$ 为独立同分布样本，$\mathcal{F}_n = (z_1,\dots,z_n)$，$\eta_0, \eta_1, \dots$ 为确定性步长，并令

$$\theta_{n+1} = \theta_n - \eta_n\nabla\ell(\theta_n; z_{n+1}), \qquad n\ge 0, \quad \theta_0 \text{ 固定.}$$

则 $\theta_n$ 是 $z_1,\dots,z_n$ 的函数，且

$$\theta_{n+1} = \theta_0 - \sum_{k=0}^n \eta_k\nabla L(\theta_k) - M_{n+1},$$
$$M_{n+1} := \sum_{k=0}^n \eta_k(\nabla\ell(\theta_k; z_{k+1}) - \nabla L(\theta_k)), \qquad M_0 := 0.$$

$(M_n)_{n\ge 0}$ 关于 $(\mathcal{F}_n)$ 逐坐标是鞅：它适应，且其差分 $\xi_{k+1} = \eta_k(\nabla\ell(\theta_k; z_{k+1}) - \nabla L(\theta_k))$ 满足 $\mathbb{E}_k\xi_{k+1} = 0$；这是对 $U = \theta_k\in L^2(\mathcal{F}_k)$ 和与 $\mathcal{F}_k$ 独立的 $Z = z_{k+1}$ 使用冻结引理，得到 $\mathbb{E}_k[\nabla\ell(\theta_k; z_{k+1})] = \nabla L(\theta_k)$。故 SGD 迭代等于 $\theta_0$ 减去累计的总体梯度步，再减去一个鞅。

**译注：**对每个确定 $\theta$ 有限的梯度二阶矩，不能保证在随机迭代点仍平方可积；还须沿迭代的可积性和 $\nabla\mathbb{E}\ell = \mathbb{E}\nabla\ell$ 的交换依据，例如适当增长 / 控制条件。反例可取中心重尾 $z$ 的密度正比 $(1+|z|)^{-4}$、$\ell(\theta; z) = e^{\theta}z$、$\theta_0 = 0, \eta_0 = \eta_1 = 1$：固定 $\theta$ 梯度二阶矩有限，但 $\theta_1 = -z_1$，下一噪声增量 $e^{-z_1}z_2$ 二阶矩无限。因此原假设不足以直接宣称所构造过程为 $L^2$ 鞅。

**例 2.5** (似然比)**. 课堂演算。**设 $Y_1, Y_2, \dots$ 独立同分布，密度为 $p$；$q$ 为另一个密度，满足 $\int q^2/p < \infty$。则

$$M_n = \prod_{k=1}^n \frac{q(Y_k)}{p(Y_k)}$$

是鞅：$\mathbb{E}_n M_{n+1} = M_n\mathbb{E}[q(Y_{n+1})/p(Y_{n+1})] = M_n\int q = M_n$。它非负且 $\mathbb{E}M_n = 1$；若 $q\ne p$，则 $M_n\to 0$ 依概率成立（习题 2.10），因此鞅可以收敛到 0 而其期望始终为 1。

**例 2.6** (Pólya 罐模型)**. 课堂演算**。一个罐中有 $r$ 个红球、$b$ 个黑球。每一步均匀随机抽取一个球，放回并增加一个同色球。记 $R_n$ 为 $n$ 次抽取后的红球数，$Y_n=\mathbf{1}\{\text{第}n\text{ 次抽到红球}\}$，$F_n=R_n/(r+b+n)$。则 $\mathbb{E}_n[R_{n+1}]=R_n+F_n$，因此

$$\mathbb{E}_n[F_{n+1}]=\frac{R_n+F_n}{r+b+n+1}=\frac{F_n(r+b+n)+F_n}{r+b+n+1}=F_n.$$

$F_n$ 是取值于 $[0,1]$ 的鞅。其差分为 $\xi_{n+1}=(Y_{n+1}-F_n)/(r+b+n+1)$，且

$$\mathbb{E}_n\xi_{n+1}^2=\frac{F_n(1-F_n)}{(r+b+n+1)^2}\le\frac{1}{4}(r+b+n+1)^{-2},$$

所以 $\sum_n\mathbb{E}\xi_n^2<\infty$。第 3 节表明这迫使 $F_n$ 收敛；习题 3.16 表明极限是随机的。

## 第 12 讲习题

**习题 2.7** (A 类)**.** 直接从第 1.1 节的方框推导命题 1.3 的规则 (iii)、(iv)，即使用 $V\subset W$ 时 $P_VP_W=P_V$，以及当 $Z\in L^2(Y)$、$g$ 有界时 $g(Y)Z\in L^2(Y)$。

**习题 2.8** (A 类)**.** 设 $(X,Y)$ 联合高斯，$X$ 为标量，$\Sigma_{YY}$ 可逆。使用定理 1.6 和各条规则，计算 $\mathbb{E}[X^2\mid Y]$ 和 $\mathbb{E}[e^X\mid Y]$。

**习题 2.9** (A 类)**. 译注：** 原题只写一阶均值。若按本文 $L^2$ Doob 鞅定义作答，还须 $f\in L^2$；仅一阶可积时可在 $L^1$ 条件期望框架写可积 Doob 鞅，但不能自动使用其二阶正交公式。

设 $Y_1,\dots,Y_N$ 独立，均值为 $\mu_k$。分别写出 $f=\sum_{k\le N}Y_k$ 和 $f=\prod_{k\le N}Y_k$ 的 Doob 鞅及其差分。

**习题 2.10** (B 类)**.** 在例 2.5 中，证明 $\mathbb{E}\sqrt{M_n}=\rho^n$，其中 $\rho=\int\sqrt{pq}<1$（当 $q\neq p$ 时），并推得对每个 $\varepsilon>0$，$\mathbb{P}(M_n\ge\varepsilon)\to0$。解释为何这不与 $\mathbb{E}M_n=1$ 或第 3 节的 $L^2$ 收敛定理矛盾。

**习题 2.11** (Efron–Stein，B 类)**.** 设 $Y_1,\dots,Y_N$ 独立，$f(Y_1,\dots,Y_N)\in L^2$；令 $Y_k'$ 为 $Y_k$ 的独立副本，且与其他所有量独立；记 $f^{(k)}$ 为把 $f$ 中 $Y_k$ 换成 $Y_k'$ 的结果。令 $\xi_k$ 为 Doob 鞅的差分。

(a) 用冻结引理证明 $\mathbb{E}_{k-1}f=\mathbb{E}_kf^{(k)}$，因而 $\xi_k=\mathbb{E}_k[f-f^{(k)}]$。

(b) 用规则 (viii) 证明 $\mathbb{E}\xi_k^2\le\mathbb{E}(f-f^{(k)})^2$。

(c) 推得 $\operatorname{Var}f\le\frac12\sum_{k\le N}\mathbb{E}(f-f^{(k)})^2$，且当 $f=\sum_k g_k(Y_k)$ 时等号成立。

**译注：** (b) 中常数 1 的界本身只能推出不含 $1/2$ 的和界。(c) 的正确 $1/2$ 还需条件方差对称性：令 $g_k=\mathbb{E}[f\mid Y_1,\dots,Y_k]$，在给定过去时对 $Y_k$ 与独立副本有 $\mathbb{E}\xi_k^2=\frac12\mathbb{E}(g_k(Y_k)-g_k(Y_k'))^2\le\frac12\mathbb{E}(f-f^{(k)})^2$，最后一步对共同未来用 Jensen。原题保留，此为缺少的额外论证。

**习题 2.12** (二次函数上的 SGD，C 类)**.** 设 $\epsilon_1,\epsilon_2,\dots$ 独立同分布、中心化，方差为 $\sigma^2$；考虑 $L(\theta)=\frac12\mathbb{E}(\theta-\epsilon)^2$ 的 SGD，步长 $\eta_k\in(0,1]$：

$$\theta_{k+1}=\theta_k-\eta_k(\theta_k-\epsilon_{k+1})=(1-\eta_k)\theta_k+\eta_k\epsilon_{k+1}.$$

(a) 仿照例 2.4(d) 写出 $\theta_{n+1}=\theta_0-\sum_{k\le n}\eta_kL'(\theta_k)-M_{n+1}$，显式给出 $M_{n+1}$。

(b) 推导 $\mathbb{E}\theta_{n+1}^2 = (1-\eta_n)^2\mathbb{E}\theta_n^2 + \eta_n^2\sigma^2$ 并求解。

(c) 证明若 $\eta_n \to 0$ 且 $\sum \eta_n = \infty$，则 $\mathbb{E}\theta_n^2 \to 0$；证明当 $\eta_n \equiv \eta$ 为常数时，$\mathbb{E}\theta_n^2 \to \eta\sigma^2/(2-\eta)$。

(d) 写出 $\theta_n = \theta_0 \prod_{k<n}(1-\eta_k) + \sum_{k<n} w_{n,k}\epsilon_{k+1}$，其中权重 $w_{n,k}$ 显式给出。($\eta_k$) 满足什么条件使 $\sum_k \eta_k\epsilon_{k+1}$ 在 $L^2$ 中收敛？（下文定理 3.10。）

# 3 分解、停时与收敛

本节始终设 $M$ 为关于第 2.1 节滤过的鞅，其差分为 $\xi_k$。

## 3.1 Doob 分解与二次变差

**命题 3.1** (Doob 分解)**.** 设 $(X_n)_{n\ge 0}$ 适应。将 $X_n = X_0 + M_n + A_n$ 写成 $M$ 为鞅、$A$ 可预测且 $M_0 = A_0 = 0$ 的形式，恰有一种方式，即

$$A_n = \sum_{k=1}^{n} (\mathbb{E}_{k-1}X_k - X_{k-1}), \qquad M_n = \sum_{k=1}^{n} (X_k - \mathbb{E}_{k-1}X_k).$$

$X$ 是次鞅当且仅当 $A$ 非减。

证明. 显示出的 $A$ 可预测，显示出的 $M$ 满足 $\mathbb{E}_{k-1}[X_k - \mathbb{E}_{k-1}X_k] = 0$，且它们之和为 $X_n - X_0$。若 $X_0 + M' + A'$ 是另一种此类分解，则 $M - M' = A' - A$ 是可预测鞅，所以 $M_n - M'_n = \mathbb{E}_{n-1}[M_n - M'_n] = M_{n-1} - M'_{n-1} = \cdots = 0$。最后的结论从 $A_n - A_{n-1} = \mathbb{E}_{n-1}X_n - X_{n-1}$ 直接读出。 □

**定义 3.2** (条件方差与二次变差)**.** 令 $\sigma_k^2 := \mathbb{E}_{k-1}[\xi_k^2]$，$\langle M\rangle_n := \sum_{k=1}^n \sigma_k^2$。

**引理 3.3.** $M_n^2$ 是次鞅，$M_n^2 - \langle M\rangle_n$ 是鞅，且 $\mathbb{E}\langle M\rangle_n = \mathbb{E}M_n^2 - \mathbb{E}M_0^2$。等价地，$\langle M\rangle$ 是 $M^2$ 的 Doob 分解中的可预测部分。

证明.

$$\begin{aligned}\mathbb{E}_{n-1}[M_n^2] - M_{n-1}^2 &= \mathbb{E}_{n-1}[(M_{n-1}+\xi_n)^2] - M_{n-1}^2 \\ &= 2M_{n-1}\mathbb{E}_{n-1}\xi_n + \mathbb{E}_{n-1}\xi_n^2 = \sigma_n^2 \ge 0.\end{aligned}$$

□

## 3.2 停时与可选停时

**定义 3.4** (停时)**.** 取值于 $\{0,1,2,\ldots\}\cup\{\infty\}$ 的随机变量 $\tau$ 若对每个 $n$ 都有 $\mathbf{1}_{\{\tau\le n\}} \in L^2(\mathcal{F}_n)$，则称为停时；即 $\tau \le n$ 是否成立是 $Y_1,\ldots,Y_n$ 的函数。

适应序列首次进入集合 $B$ 的时间 $\min\{n : X_n \in B\}$ 是停时；对常数 $N$，$\tau \wedge N = \min(\tau, N)$ 也是停时；最后一次访问 $B$ 则不是。对停时 $\tau$，停止后的序列为 $(M_{n\wedge\tau})_{n\ge 0}$。

**命题 3.5** (停止后的鞅)**.** 若 $M$ 是鞅（次鞅、上鞅）且 $\tau$ 为停时，则 $(M_{n\wedge\tau})_{n\ge 0}$ 是鞅（次鞅、上鞅），其差分为 $\mathbf{1}_{\{\tau>n\}}\xi_{n+1}$。

证明. $M_{n\wedge\tau}$ 是 $Y_1,\dots,Y_n$ 的函数且属于 $L^2$（它是 $M_0,\dots,M_n$ 之一）。由于 $M_{(n+1)\wedge\tau}-M_{n\wedge\tau}=\mathbf{1}_{\{\tau>n\}}\xi_{n+1}$，且 $\mathbf{1}_{\{\tau>n\}}=1-\mathbf{1}_{\{\tau\le n\}}\in L^2(\mathcal{F}_n)$ 有界，由规则 (iii)，$\mathbb{E}_n[\mathbf{1}_{\{\tau>n\}}\xi_{n+1}]=\mathbf{1}_{\{\tau>n\}}\mathbb{E}_n\xi_{n+1}$，它等于 0（分别为 $\ge 0$、$\le 0$）。 □

**推论 3.6** (可选停时，有界情形)**.** 设停时 $\tau\le N$，受常数 $N$ 约束。若 $M$ 是鞅，则 $\mathbb{E}M_\tau=\mathbb{E}M_0$。若 $X$ 是次鞅，则 $\mathbb{E}X_0\le\mathbb{E}X_\tau\le\mathbb{E}X_N$；上鞅的不等式方向相反。

证明. $M_\tau=M_{N\wedge\tau}$，而停止后的鞅均值恒定，故 $\mathbb{E}M_\tau=\mathbb{E}M_{0\wedge\tau}=\mathbb{E}M_0$；对次鞅，同一论证给出 $\mathbb{E}X_\tau\ge\mathbb{E}X_0$。对上界，

$$X_N-X_\tau=\sum_{k=1}^{N}\mathbf{1}_{\{\tau\le k-1\}}(X_k-X_{k-1}),$$

且每项满足

$$\mathbb{E}[\mathbf{1}_{\{\tau\le k-1\}}(X_k-X_{k-1})]=\mathbb{E}[\mathbf{1}_{\{\tau\le k-1\}}\mathbb{E}_{k-1}(X_k-X_{k-1})]\ge 0.$$

□

不能去掉 $\tau$ 有界这一条件：对简单随机游走和 $\tau=\min\{n:S_n=1\}$，$\mathbb{E}S_\tau=1\ne 0=\mathbb{E}S_0$。对无界的 $\tau$，可将推论用于 $\tau\wedge n$ 并取极限，如下所示。

**例 3.7** (赌徒破产)**. 课堂演算**。设 $S$ 是简单对称随机游走，$a,b$ 为正整数，$\tau=\min\{n:S_n\in\{-b,a\}\}$，$c=\max(a,b)$。

$\tau$ **有限**。$S_n^2-n$ 是鞅（例 2.4(a)），$\tau\wedge n$ 有界，故 $\mathbb{E}(\tau\wedge n)=\mathbb{E}S_{\tau\wedge n}^2\le c^2$。因此 $\mathbb{P}(\tau>n)=\mathbb{P}(\tau\wedge n=n)\le\mathbb{E}(\tau\wedge n)/n\le c^2/n\to 0$。

**译注：** 原文首个等号有端点错误：$\{\tau\wedge n=n\}=\{\tau\ge n\}$，不是 $\{\tau>n\}$。将首个等号改读为 $\le$ 即可保留尾界及赌徒破产结论；例如 $a=b=1,n=1$ 时两事件概率分别为 0 和 1。

**退出概率**。$0=\mathbb{E}S_{\tau\wedge n}$，且 $|S_{\tau\wedge n}-S_\tau\mathbf{1}_{\{\tau\le n\}}|\le c\mathbf{1}_{\{\tau>n\}}$，所以 $|\mathbb{E}[S_\tau\mathbf{1}_{\{\tau\le n\}}]|\le c\mathbb{P}(\tau>n)\to 0$。令 $p=\mathbb{P}(S_\tau=a)$，得到 $pa-(1-p)b=0$，即

$$\mathbb{P}(S_\tau=a)=\frac{b}{a+b},\qquad \mathbb{P}(S_\tau=-b)=\frac{a}{a+b}.$$

**期望退出时间**。$\mathbb{E}(\tau\wedge n)=\mathbb{E}S_{\tau\wedge n}^2\to\mathbb{E}S_\tau^2=a^2\frac{b}{a+b}+b^2\frac{a}{a+b}=ab$。左侧的收敛为 $\mathbb{E}(\tau\wedge n)=\sum_{m<n}\mathbb{P}(\tau>m)\uparrow\mathbb{E}\tau$，右侧同上。故 $\mathbb{E}\tau=ab$。

**例 3.8** (Wald 恒等式)**. 课堂演算**。设 $Y_1,Y_2,\dots$ 独立同分布，均值为 $\mu$、方差有限，$S_n=\sum_{k\le n}Y_k$，$\tau$ 是满足 $\mathbb{E}\tau<\infty$ 的停时。则 $\mathbb{E}S_\tau=\mu\mathbb{E}\tau$。证明：$S_n-n\mu$ 是鞅，故由推论 3.6，$\mathbb{E}S_{\tau\wedge n}=\mu\mathbb{E}(\tau\wedge n)$，右侧趋于 $\mu\mathbb{E}\tau$。对左侧写

$$S_\tau-S_{\tau\wedge n}=\sum_{k>n}\mathbf{1}_{\{\tau\ge k\}}(Y_k-\mu)+\mu(\tau-n)_+.$$

第一项之和的各项为鞅差，因为 $\mathbf{1}_{\{\tau\ge k\}}\in L^2(\mathcal{F}_{k-1})$。由引理 2.3，其二阶矩为

$$\operatorname{Var}(Y_1)\sum_{k>n}\mathbb{P}(\tau\ge k)=\operatorname{Var}(Y_1)\mathbb{E}(\tau-n)_+.$$

因此

$$\mathbb{E}|S_\tau-S_{\tau\wedge n}|\le\sqrt{\operatorname{Var}(Y_1)\mathbb{E}(\tau-n)_+}+|\mu|\mathbb{E}(\tau-n)_+\longrightarrow 0,$$

且 $\mathbb{E}S_{\tau\wedge n}\to\mathbb{E}S_\tau$。

### 3.3 最大不等式与 $L^2$ 收敛

**命题 3.9** (Doob 最大不等式)**.** 对每个 $n$ 和 $u>0$，

$$\mathbb{P}\left(\max_{k\le n}|M_k|\ge u\right)\le\frac{\mathbb{E}M_n^2}{u^2},\qquad\qquad \mathbb{E}\max_{k\le n}M_k^2\le 4\mathbb{E}M_n^2.$$

*证明.* 令 $\tau=\min\{k\le n:|M_k|\ge u\}$；若不存在这样的 $k$ 则令 $\tau=n$。$\tau\le n$ 为停时。$M^2$ 是次鞅（引理 3.3），所以由推论 3.6，

$$\mathbb{E}M_n^2\ge\mathbb{E}M_\tau^2\ge\mathbb{E}[M_\tau^2\mathbf{1}_{\{\max_{k\le n}|M_k|\ge u\}}]\ge u^2\mathbb{P}\left(\max_{k\le n}|M_k|\ge u\right).$$

第二个不等式是习题 3.13。 □

**定理 3.10** ($L^2$ 收敛)**.** 假设 $\sum_{k\ge1}\mathbb{E}\xi_k^2<\infty$，等价地 $\sup_n\mathbb{E}M_n^2<\infty$。则：

(i) 存在 $M_\infty\in L^2$ 使 $\mathbb{E}(M_n-M_\infty)^2=\sum_{k>n}\mathbb{E}\xi_k^2\to0$，且对每个 $n$ 有 $\mathbb{E}_nM_\infty=M_n$；

(ii) 对每个 $n$ 和 $u>0$，$\mathbb{P}(\sup_{k\ge n}|M_k-M_n|\ge u)\le u^{-2}\sum_{k>n}\mathbb{E}\xi_k^2$。

*证明.* (i) 对 $n<m$，$\mathbb{E}(M_n-M_m)^2=\sum_{k=n+1}^m\mathbb{E}\xi_k^2$（引理 2.3），故 $(M_n)$ 在 $L^2$ 中为 Cauchy 序列，由完备性收敛到某个 $M_\infty$，且 $\mathbb{E}(M_n-M_\infty)^2=\lim_m\mathbb{E}(M_n-M_m)^2$。由于 $m\ge n$ 时 $\mathbb{E}_nM_m=M_n$，而 $\mathbb{E}_n$ 为收缩映射（规则 (viii)），故 $\mathbb{E}_nM_\infty=\lim_m\mathbb{E}_nM_m=M_n$。(ii) 固定 $n$，$(M_k-M_n)_{k\ge n}$ 是鞅，差分为 $k>n$ 时的 $\xi_k$。对时间范围 $m$ 应用命题 3.9，得到 $\mathbb{P}(\max_{n\le k\le m}|M_k-M_n|\ge u)\le u^{-2}\sum_{k=n+1}^m\mathbb{E}\xi_k^2$；令 $m\to\infty$。 □

陈述 (ii) 控制时间 $n$ 之后路径的整个未来；后面将以此形式使用收敛性。

**译注：** 对有限时域令其增大直接控制的是“某个时刻达到阈值”，而 $\sup\ge u$ 可能只逼近 $u$。可先对任意 $b<u$ 用最大不等式，利用 $\{\sup\ge u\}\subset\{\exists k:|M_k-M_n|\ge b\}$，再令 $b\uparrow u$，补足端点细节。

**例 3.11** (加权和)**.** 设 $\epsilon_1,\epsilon_2,\dots$ 为鞅差，$\mathbb{E}_{k-1}\epsilon_k^2\le1$，$a_k$ 可预测且有界，并满足 $\sum_k\mathbb{E}a_k^2<\infty$。则 $M_n=\sum_{k\le n}a_k\epsilon_k$ 为鞅，其 $\sigma_k^2=a_k^2\mathbb{E}_{k-1}\epsilon_k^2\le a_k^2$，定理 3.10 适用。特别地，对确定性 $\eta_k$，只要 $\sum_k\eta_k^2<\infty$，$\sum_k\eta_k\epsilon_k$ 就在 $L^2$ 中收敛。这是 SGD 步长的 Robbins–Monro 条件（第 16 讲）。

**例 3.12** (随机级数)**. 课堂演算。**设 $\epsilon_k$ 为独立同分布的随机符号。$\sum_k\epsilon_k/k$ 在 $L^2$ 中收敛，因为 $\sum_k k^{-2}<\infty$。$\sum_k\epsilon_k/\sqrt{k}$ 则不收敛：$\mathbb{E}M_n^2=\sum_{k\le n}1/k\to\infty$，而 $\mathbb{E}(M_m-M_n)^2=\sum_{n<k\le m}1/k$ 当 $n,m\to\infty$ 时不趋于零。对 Pólya 罐模型（例 2.6），$\sum_n\mathbb{E}\xi_n^2<\infty$，故 $F_n\to F_\infty$ 于 $L^2$ 中，且 $\mathbb{E}F_\infty=r/(r+b)$。

### 第 13 讲习题

**习题 3.13** (B 类)**.** 令 $M_n^*=\max_{k\le n}|M_k|$。

(a) 证明 $|M|$ 是次鞅（规则 (vi)）。

(b) 精化命题 3.9 的证明，得到 $u\mathbb{P}(M_n^*\ge u)\le\mathbb{E}[|M_n|\mathbf{1}_{\{M_n^*\ge u\}}]$。

(c) 使用 $\mathbb{E}Z^2=\int_0^\infty 2u\mathbb{P}(Z\ge u)\,du$ 和 Cauchy–Schwarz，推得 $\mathbb{E}(M_n^*)^2\le 4\mathbb{E}M_n^2$。

**习题 3.14** (A 类)**.** 对下列过程计算 $\langle M\rangle_n$：简单随机游走；例 2.4(a) 的指数鞅；$f=\sum_{k\le N}Y_k$、$Y_k$ 独立时的 Doob 鞅；例 2.5 的似然比。

**习题 3.15** (B 类)**.** 设 $S$ 为简单对称随机游走，$\tau_1=\min\{n:S_n=1\}$。

(a) 在例 3.7 中取 $a=1$ 并令 $b\to\infty$，证明 $\mathbb{P}(\tau_1<\infty)=1$。

(b) 证明 $\mathbb{E}\tau_1=\infty$（若有限，Wald 恒等式将给出 $1=\mathbb{E}S_{\tau_1}=0$）。

(c) 对鞅 $e^{\lambda S_n}/(\cosh\lambda)^n$ 在 $\tau_1\wedge n$ 处应用推论 3.6，令 $n\to\infty$，计算 $\lambda>0$ 时的 $\mathbb{E}[(\cosh\lambda)^{-\tau_1}]$。

**习题 3.16** (Pólya 罐模型的完成，B 类)**.** 接续例 2.6。

(a) 对 $r=b=1$，归纳证明 $R_n$ 在 $\{1,\dots,n+1\}$ 上均匀，从而 $L^2$ 极限 $F_\infty$ 在 $[0,1]$ 上均匀。

(b) 由条件方差计算一般 $r,b$ 的 $\operatorname{Var}F_n$，并确定 $\operatorname{Var}F_\infty$。

(c) 证明 $\mathbb{E}[F_\infty\mid F_n]=F_n$ 并解释：罐中最终组成是随机的，但时间 $n$ 时对它的最佳猜测是当前比例。

**习题 3.17** (分支过程，C 类)**.** 设 $Z_0=1$、$Z_{n+1}=\sum_{i=1}^{Z_n}\zeta_{n+1,i}$，其中各 $\zeta_{n,i}$ 为独立同分布的非负整数，均值为 $m$、方差为 $s^2$，且独立于过去。

(a) 用冻结引理证明 $\mathbb{E}_nZ_{n+1}=mZ_n$，故 $W_n=Z_n/m^n$ 是鞅。

(b) 用定义 1.4 证明 $\operatorname{Var}Z_{n+1}=s^2m^n+m^2\operatorname{Var}Z_n$，因此 $\operatorname{Var}W_{n+1}=\operatorname{Var}W_n+s^2/m^{n+2}$。

(c) 当 $m>1$ 时推得 $\sup_n\mathbb{E}W_n^2<\infty$，所以 $W_n\to W_\infty$ 于 $L^2$，且 $\mathbb{E}W_\infty=1$、$\operatorname{Var}W_\infty=s^2/[m(m-1)]$。

(d) 对 $m=1.5$ 的 Poisson 子代进行模拟，画出若干次运行中 $W_n$ 的轨迹。

# 4 鞅中心极限定理

第 3–4 讲逐个将独立求和项替换为高斯变量，证明了中心极限定理。对鞅差而言，每一步的条件方差是随机的，所以混合变量中的高斯部分被设定为携带剩余的条件方差。

## 4.1 陈述

固定 $k$ 及鞅差 $\xi_1,\dots,\xi_k$，满足 $\mathbb{E}|\xi_i|^3<\infty$，条件方差 $\sigma_i^2=\mathbb{E}_{i-1}\xi_i^2$，并令

$$S_j=\sum_{i\le j}\xi_i,\qquad V_j=\sum_{i\le j}\sigma_i^2=\langle S\rangle_j,\qquad S_0=V_0=0.$$

**定理 4.1** (鞅中心极限定理，定量形式)**.** 假设 $V_k\le 1$。则对每个 $f\in C^4(\mathbb{R})$，其 $f',f'',f''',f''''$ 有界，且 $g\sim\mathcal{N}(0,1)$，

$$|\mathbb{E}f(S_k)-\mathbb{E}f(g)|\le\frac{\|f'''\|_\infty}{6}\sum_{i=1}^k\mathbb{E}|\xi_i|^3+\frac{\|f''''\|_\infty}{8}\sum_{i=1}^k\mathbb{E}\sigma_i^4+\frac{\|f''\|_\infty}{2}\mathbb{E}(1-V_k).$$

由于 $\sum_i\sigma_i^4\le V_k\max_i\sigma_i^2\le\max_i\sigma_i^2$，第二项至多为 $\frac18\|f''''\|_\infty\mathbb{E}\max_i\sigma_i^2$。

**推论 4.2** (鞅中心极限定理)**.** 对每个 $n$，设 $\xi_{n,1},\dots,\xi_{n,k_n}$ 为鞅差（滤过可依赖于 $n$），条件方差为 $\sigma_{n,i}^2$，且 $V_{n,k_n}=\sum_i \sigma_{n,i}^2 \le 1$。若

$$\sum_i \mathbb{E}|\xi_{n,i}|^3 \to 0, \qquad \mathbb{E}\max_i \sigma_{n,i}^2 \to 0, \qquad \mathbb{E}(1-V_{n,k_n}) \to 0,$$

则 $\sum_i \xi_{n,i} \Rightarrow \mathcal{N}(0,1)$。

*证明.* 由定理 4.1，对所有各阶导数均有界的光滑 $f$，$\mathbb{E}f(S_{n,k_n}) \to \mathbb{E}f(g)$；而这类检验函数决定依分布收敛（第 3–4 讲）。 □

## 4.2 证明

**引理 4.3** (热半群)**.** 对定理 4.1 中的 $f$ 和 $g\sim\mathcal{N}(0,1)$，令 $\phi(x,v)=\mathbb{E}f(x+\sqrt{v}\,g)$，$x\in\mathbb{R}$、$v\ge 0$。则 $\phi(x,0)=f(x)$、$\phi(0,1)=\mathbb{E}f(g)$，且 $\partial_x^j\phi(x,v)=\mathbb{E}f^{(j)}(x+\sqrt{v}\,g)$，故 $\|\partial_x^j\phi\|_\infty \le \|f^{(j)}\|_\infty$ $(j\le 4)$。对 $v>0$，

$$\partial_v\phi = \tfrac{1}{2}\partial_{xx}\phi.$$

因此对 $0\le v'<v$，$\phi(x,v)-\phi(x,v')=\frac{1}{2}\int_{v'}^{v}\partial_{xx}\phi(x,s)\,ds$。

*证明.* 导数有界保证可在 $\mathbb{E}$ 内求导。对热方程，将 Stein 恒等式 $\mathbb{E}[gh(g)]=\mathbb{E}h'(g)$（第 3–4 讲）应用于 $h(y)=f'(x+\sqrt{v}\,y)$：

$$\partial_v\phi(x,v)=\mathbb{E}\left[f'(x+\sqrt{v}\,g)\frac{g}{2\sqrt{v}}\right]=\frac{1}{2\sqrt{v}}\mathbb{E}h'(g)=\frac{1}{2}\mathbb{E}f''(x+\sqrt{v}\,g).$$

当 $v'>0$ 时积分公式由微积分基本定理成立；利用 $|\phi(x,v')-\phi(x,0)|\le\|f'\|_\infty\sqrt{v'}\,\mathbb{E}|g|$，令 $v'\downarrow 0$。 □

*定理 4.1 的证明.* 由于 $\phi(S_0,1-V_0)=\mathbb{E}f(g)$ 且 $\phi(S_k,0)=f(S_k)$，

$$\begin{aligned}\mathbb{E}f(S_k)-\mathbb{E}f(g) &= \mathbb{E}[\phi(S_k,0)-\phi(S_k,1-V_k)]\\ &\quad+\sum_{i=1}^{k}\mathbb{E}[\phi(S_i,1-V_i)-\phi(S_{i-1},1-V_{i-1})].\end{aligned}$$

**第一项**。由积分公式，$|\phi(x,0)-\phi(x,v)|\le\frac{v}{2}\|f''\|_\infty$，故第一项的绝对值至多为 $\frac{1}{2}\|f''\|_\infty\mathbb{E}(1-V_k)$。

**第 $i$ 步**。写 $x=S_{i-1}$、$v=1-V_{i-1}$、$\sigma^2=\sigma_i^2$、$\xi=\xi_i$；则 $x,v,\sigma^2\in L^2(\mathcal{F}_{i-1})$，且 $v-\sigma^2=1-V_i\ge 0$。拆分

$$\begin{aligned}\phi(x+\xi,v-\sigma^2)-\phi(x,v) &= \underbrace{\phi(x+\xi,v-\sigma^2)-\phi(x,v-\sigma^2)}_{I}\\ &\quad+\underbrace{\phi(x,v-\sigma^2)-\phi(x,v)}_{II}.\end{aligned}$$

对 $x$ 作 Taylor 展开：

$$I=\xi\partial_x\phi(x,v-\sigma^2)+\tfrac{\xi^2}{2}\partial_{xx}\phi(x,v-\sigma^2)+R, \qquad |R|\le\frac{\|f'''\|_\infty}{6}|\xi|^3.$$

系数有界且属于 $L^2(\mathcal{F}_{i-1})$，故由规则 (iii)，

$$\mathbb{E}_{i-1} I = \frac{\sigma^2}{2}\partial_{xx}\phi(x, v-\sigma^2) + \mathbb{E}_{i-1}R.$$

由积分公式，

$$\begin{aligned} II &= -\frac{1}{2}\int_{v-\sigma^2}^{v} \partial_{xx}\phi(x,s)\,ds \\ &= -\frac{\sigma^2}{2}\partial_{xx}\phi(x, v-\sigma^2) - \frac{1}{2}\int_{v-\sigma^2}^{v} [\partial_{xx}\phi(x,s) - \partial_{xx}\phi(x, v-\sigma^2)]\,ds, \end{aligned}$$

于是 $\mathbb{E}_{i-1}I$ 与 $II$ 的主项抵消。由于 $\partial_s\partial_{xx}\phi = \frac{1}{2}\partial_x^4\phi$ 由 $\frac{1}{2}\|f''''\|_\infty$ 约束，被积函数的绝对值至多为 $\frac{1}{2}\|f''''\|_\infty(s - v + \sigma^2)$，积分项至多为

$$\frac{1}{4}\|f''''\|_\infty \int_0^{\sigma^2} t\,dt = \frac{\|f''''\|_\infty}{8}\sigma^4.$$

因此

$$|\mathbb{E}_{i-1}[I + II]| \le \frac{\|f'''\|_\infty}{6}\mathbb{E}_{i-1}|\xi_i|^3 + \frac{\|f''''\|_\infty}{8}\sigma_i^4.$$

取期望并对 $i$ 求和。 □

**注 4.4** (去掉 $V_k \le 1$)**.** $\{V_i \le 1\}$ 在时间 $i-1$ 已确定（因为 $V_i = V_{i-1} + \sigma_i^2$，且 $\sigma_i^2 \in L^2(\mathcal{F}_{i-1})$），所以 $\xi_i' = \xi_i \mathbf{1}_{\{V_i \le 1\}}$ 是鞅差，其条件方差为 $\sigma_i^2 \mathbf{1}_{\{V_i\le 1\}}$，累计方差 $V_k' \le 1$。由引理 2.3，

$$\mathbb{E}(S_k - S_k')^2 = \mathbb{E}\sum_{i:V_i>1}\sigma_i^2 \le \mathbb{E}(V_k - 1)_+ + \mathbb{E}\max_i \sigma_i^2.$$

所以将定理 4.1 应用于 $S_k'$，便可在上述误差范围内控制 $S_k$；并且推论 4.2 中的 $V_{n,k_n} \le 1$ 可换成 $\mathbb{E}|V_{n,k_n} - 1| \to 0$。

**注 4.5** (独立求和项)**.** 若 $\xi_i$ 独立，方差 $\sigma_i^2$ 之和为 1，则 $V_k = 1$，界变为

$$|\mathbb{E}f(S_k) - \mathbb{E}f(g)| \le \frac{\|f'''\|_\infty}{6}\sum_i \mathbb{E}|\xi_i|^3 + \frac{\|f''''\|_\infty}{8}\sum_i \sigma_i^4.$$

第 3–4 讲的混合变量 $\sum_{j\le i}\xi_j + \sum_{j>i} g_j$ 现在变成 $S_i + \sqrt{1-V_i}\,g$。

### 4.3 例子

**例 4.6** (独立同分布的求和项)**. 课堂演算**。设 $X_1, \dots, X_n$ 独立同分布、中心化，方差为 1 且 $\mathbb{E}|X_1|^3 < \infty$，令 $\xi_i = X_i/\sqrt{n}$。则 $\sigma_i^2 = 1/n$、$V_n = 1$、$\sum \mathbb{E}|\xi_i|^3 = \mathbb{E}|X_1|^3/\sqrt{n}$、$\sum \sigma_i^4 = 1/n$，由定理 4.1，

$$|\mathbb{E}f(S_n) - \mathbb{E}f(g)| \le \frac{\|f'''\|_\infty \mathbb{E}|X_1|^3}{6\sqrt{n}} + \frac{\|f''''\|_\infty}{8n}.$$

**例 4.7** (自适应收集的数据)**. 课堂演算**。设 $\epsilon_1, \epsilon_2, \dots$ 独立同分布、中心化，方差为 1 且 $\mathbb{E}|\epsilon_1|^3 < \infty$，适应于滤过 $(\mathcal{F}_i)$，其中 $\epsilon_i$ 与 $\mathcal{F}_{i-1}$ 独立。设 $a_i$ 可预测且 $|a_i| \le A$。则 $\xi_i = a_i\epsilon_i$ 是鞅差，且

$$\sigma_i^2 = a_i^2, \qquad \mathbb{E}_{i-1}|\xi_i|^3 = |a_i|^3\mathbb{E}|\epsilon_1|^3, \qquad V_k = \sum_{i\le k} a_i^2.$$

令确定性的 $v_k \to \infty$ 满足 $\mathbb{E}|V_k/v_k - 1| \to 0$。归一化差分 $a_i\epsilon_i/\sqrt{v_k}$ 满足

$$\sum_i \mathbb{E}|\cdot|^3 \le A\mathbb{E}|\epsilon_1|^3 \mathbb{E}V_k / v_k^{3/2} \to 0, \qquad \max_i \sigma_i^2/v_k \le A^2/v_k \to 0.$$

因此由推论 4.2 和注 4.4，

$$\frac{1}{\sqrt{v_k}} \sum_{i\le k} a_i\epsilon_i \Rightarrow \mathcal{N}(0,1).$$

这涵盖协变量 $a_i$ 选为过去响应的函数时的最小二乘（多臂老虎机、主动学习、序贯实验）：见习题 4.10、4.11。

## 第 14 讲习题

**习题 4.8** (A 类)**.** 设 $\xi_i$ 独立、中心化，方差为 $\sigma_i^2$，且 $\sum_{i\le k}\sigma_i^2 = 1$。从定理 4.1 推得第 3–4 讲的 Lindeberg 定理（在三阶矩条件下），并比较误差界。

**习题 4.9** (A 类)**.** 当 $f(x) = e^{i\theta x}$ 以及 $f(x) = x^4$ 时，直接验证 $\phi(x,v) = \mathbb{E}f(x + \sqrt{v}\,g)$ 求解 $\partial_v\phi = \tfrac{1}{2}\partial_{xx}\phi$。

**习题 4.10** (双臂老虎机，B 类)**.** 两只臂给出奖励 $\mu_1 + \epsilon$ 和 $\mu_2 + \epsilon$，其中 $\epsilon$ 如例 4.7。每轮玩家以概率 $1-\delta$ 选择当前经验均值较大的臂，以概率 $\delta \in (0, 1/2)$ 选择另一只臂，所用硬币独立。令 $N_1(n)$ 为前 $n$ 轮选择臂 1 的次数，$\widehat{\mu}_1(n)$ 为其经验均值。

(a) 证明 $N_1(n)$ 支配一个 $\mathrm{Bin}(n,\delta)$ 变量，故 $N_1(n) \to \infty$。

(b) 写出 $N_1(n)(\widehat{\mu}_1(n) - \mu_1) = \sum_{i\le n} a_i\epsilon_i$，其中 $a_i \in \{0,1\}$ 可预测。

(c) 假设 $N_1(n)/n \to p_1 \in (0,1)$ 于 $L^2$，证明 $\sqrt{N_1(n)}(\widehat{\mu}_1(n) - \mu_1) \Rightarrow \mathcal{N}(0,1)$。

**习题 4.11** (自回归的最小二乘，C 类)**.** 设 $X_0 = 0$、$X_{k+1} = \rho X_k + \epsilon_{k+1}$，其中 $|\rho| < 1$，$\epsilon_k$ 独立同分布于 $\mathcal{N}(0,\sigma^2)$。由 $X_0,\dots,X_n$ 得到的 $\rho$ 的最小二乘估计满足

$$\widehat{\rho}_n - \rho = \frac{\sum_{k<n} X_k\epsilon_{k+1}}{\sum_{k<n} X_k^2}.$$

(a) 证明分子 $M_n$ 是鞅，且 $\sigma_{k+1}^2 = \sigma^2 X_k^2$。

(b) 证明 $\mathbb{E}X_k^2 \to \sigma^2/(1-\rho^2)$，且 $\mathrm{Var}(n^{-1}\sum_{k<n}X_k^2) = O(1/n)$（对四阶矩使用 Wick 定理；$\mathrm{Cov}(X_j^2, X_k^2)$ 按 $|j-k|$ 几何衰减），故 $n^{-1}\sum_{k<n}X_k^2 \to \sigma^2/(1-\rho^2)$ 于 $L^2$。

(c) 对 $M_n/\sqrt{n\sigma^4/(1-\rho^2)}$ 应用推论 4.2 与注 4.4，推得 $\sqrt{n}(\widehat{\rho}_n - \rho) \Rightarrow \mathcal{N}(0, 1-\rho^2)$（可引用：除以一个依概率收敛到正的常数的序列不改变依分布极限）。

(d) 对 $\rho = 0.9$、$n = 2000$ 模拟 $10^3$ 次，与预测的高斯分布比较。

**译注：** 括号内 Slutsky 说法若指极限分布不变则不正确：$A_n \Rightarrow A$、$B_n \to c > 0$ 依概率蕴含 $A_n/B_n \Rightarrow A/c$。本题已写的 $\mathcal{N}(0, 1-\rho^2)$ 正确计入了该缩放，且需要非退化噪声以定义估计量。

**习题 4.12** (二次函数上的 SGD：涨落，C 类)**.** 在习题 2.12 中取 $\eta_k = \eta/k$，其中 $\eta > 1/2$ 且 $\mathbb{E}|\epsilon_1|^3 < \infty$。

**译注：**此前迭代从 $k=0$ 起，而 $\eta/k$ 在 0 无定义，须约定正指标起点或另给初始步；$\eta > 1$ 也可能使初期步长违反先前 $\eta_k \le 1$。原题 (a) 的相对渐近不对所有固定早期 $k$ 一致：对正指标 $w_{n,k} = (\eta/k)\prod_{j=k+1}^{n-1}(1-\eta/j)$，$\eta = 3/4, k = 1$ 时，与 $(\eta/k)(k/n)^\eta$ 的比趋于 $1/\Gamma(5/4) \simeq 1.10326265$，不是 1。通常须 $k$ 增长，早期权重另控；此处保留原题，不补造自举证明。

(a) 证明权重满足 $w_{n,k} = \frac{\eta}{k}(k/n)^\eta(1+o(1))$，对 $k \le n$ 一致成立。

(b) 证明 $n \operatorname{Var}\theta_n \to \eta^2\sigma^2/(2\eta-1)$。

(c) 应用定理 4.1（各求和项独立，故 $V_k$ 确定）证明 $\sqrt{n}\,\theta_n \Rightarrow \mathcal{N}(0, \eta^2\sigma^2/(2\eta-1))$。当 $\eta < 1/2$ 时有什么变化？

# 5 集中不等式

本节始终设 $M$ 为鞅，差分为 $\xi_k$，条件方差为 $\sigma_k^2$。

## 5.1 Azuma–Hoeffding 不等式

**引理 5.1** (Hoeffding 引理)**.** 设 $\mathbb{E}\xi = 0$，且对常数 $a, c$ 有 $a \le \xi \le a + c$。则对所有 $\lambda \in \mathbb{R}$，$\mathbb{E}e^{\lambda\xi} \le e^{\lambda^2 c^2/8}$。条件形式：若 $\mathbb{E}_{k-1}\xi = 0$、$A \le \xi \le A + c$，其中 $A \in L^2(\mathcal{F}_{k-1})$、$c$ 为常数，则 $\mathbb{E}_{k-1}e^{\lambda\xi} \le e^{\lambda^2 c^2/8}$。

*证明.* 我们证明 $|\xi| \le c$ 的情形，常数为 $e^{\lambda^2 c^2/2}$；尖锐常数留作习题 5.13。由 $x \mapsto e^{\lambda x}$ 在 $[-c, c]$ 上的凸性，

$$e^{\lambda\xi} \le \frac{c-\xi}{2c}e^{-\lambda c} + \frac{c+\xi}{2c}e^{\lambda c},$$

故 $\mathbb{E}e^{\lambda\xi} \le \cosh(\lambda c) \le e^{\lambda^2 c^2/2}$；最后一步通过比较 Taylor 级数得到（$(2k)! \ge 2^k k!$）。条件形式对 $\mathbb{E}_{k-1}$ 作相同计算即可（规则 (iii)、(vi)）。 □

**定理 5.2** (Azuma–Hoeffding)**.** 假设 $A_k \le \xi_k \le A_k + c_k$，其中 $A_k$ 可预测、$c_k$ 为常数。则对每个 $u > 0$，

$$\mathbb{P}(M_n - M_0 \ge u) \le \exp\left(-\frac{2u^2}{\sum_{k\le n} c_k^2}\right),$$

且 $\mathbb{P}(M_n - M_0 \le -u)$ 有相同的界。

*证明.* 由规则 (ii)–(iv) 和引理 5.1，

$$\begin{aligned}\mathbb{E}e^{\lambda(M_n - M_0)} &= \mathbb{E}[e^{\lambda(M_{n-1}-M_0)}\mathbb{E}_{n-1}e^{\lambda\xi_n}] \\ &\le e^{\lambda^2 c_n^2/8}\mathbb{E}e^{\lambda(M_{n-1}-M_0)} \le \cdots \le \exp\left(\frac{\lambda^2}{8}\sum_{k\le n}c_k^2\right).\end{aligned}$$

对 Chernoff 界 $\mathbb{P}(M_n - M_0 \ge u) \le e^{-\lambda u}\mathbb{E}e^{\lambda(M_n-M_0)}$ 取 $\lambda = 4u/\sum c_k^2$，得到结论；对 $-M$ 应用即可得下尾界。 □

对简单随机游走，$\mathbb{P}(S_n \ge u) \le e^{-u^2/(2n)}$。

## 5.2 McDiarmid 不等式

**定理 5.3** (有界差分)**.** 设 $Y_1,\dots,Y_N$ 独立，$f$ 有界，且对所有参数和所有 $k$，

$$|f(y_1,\dots,y_N) - f(y_1,\dots,y_{k-1},y_k',y_{k+1},\dots,y_N)| \le c_k.$$

则对每个 $u>0$，

$$\mathbb{P}(f(Y) - \mathbb{E}f(Y) \ge u) \le \exp\left(-\frac{2u^2}{\sum_{k\le N} c_k^2}\right),$$

下尾有同样的界。

证明. 令 $M_k = \mathbb{E}_k f$ 为 Doob 鞅。由冻结引理，$M_k = g_k(Y_1,\dots,Y_k)$，其中 $g_k(y_1,\dots,y_k) = \mathbb{E}f(y_1,\dots,y_k,Y_{k+1},\dots,Y_N)$；当参数只在第 $k$ 位不同时，$|g_k(\dots,y,\dots) - g_k(\dots,y',\dots)| \le c_k$。因此给定 $Y_1,\dots,Y_{k-1}$ 时，差分 $\xi_k = g_k(Y_1,\dots,Y_k) - g_{k-1}(Y_1,\dots,Y_{k-1})$ 位于 $[A_k, A_k + c_k]$，其中

$$A_k = \inf_y g_k(Y_1,\dots,Y_{k-1},y) - g_{k-1}(Y_1,\dots,Y_{k-1})$$

可预测。对 $M_N - M_0 = f - \mathbb{E}f$ 应用定理 5.2。 □

**例 5.4** (Hoeffding 不等式)**.** 对 $f = n^{-1}\sum_{i\le n} Y_i$，其中 $Y_i \in [0,1]$，$c_i = 1/n$，且 $\mathbb{P}(\overline{Y}_n - \mathbb{E}\overline{Y}_n \ge u) \le e^{-2nu^2}$。

**例 5.5** (泛化差距)**. 课堂演算**。设 $z_1,\dots,z_n$ 独立同分布，$\mathcal{H}$ 为预测器类，$\ell(h,z)\in[0,1]$ 为损失，$L(h) = \mathbb{E}\ell(h,z)$、$\widehat{L}_n(h) = n^{-1}\sum_i \ell(h,z_i)$，并令

$$Z = \sup_{h\in\mathcal{H}} (L(h) - \widehat{L}_n(h)).$$

改变一个 $z_i$ 使每个 $\widehat{L}_n(h)$，从而 $Z$，改变至多 $1/n$。对任意类别 $\mathcal{H}$，定理 5.3 给出 $\mathbb{P}(Z \ge \mathbb{E}Z + u) \le e^{-2nu^2}$。

**命题 5.6** (对称化)**.** 设 $\epsilon_1,\dots,\epsilon_n$ 为相互独立、与数据独立的均匀随机符号，则

$$\mathbb{E}Z \le 2\mathbb{E}\sup_{h\in\mathcal{H}} \frac{1}{n}\sum_{i\le n} \epsilon_i \ell(h,z_i).$$

证明. 令 $z_1',\dots,z_n'$ 为数据的独立副本，$\mathbb{E}'$ 表示对副本取期望，则 $L(h) = \mathbb{E}'\widehat{L}_n'(h)$。于是

$$\begin{aligned}\mathbb{E}Z &= \mathbb{E}\sup_h \mathbb{E}'[\widehat{L}_n'(h) - \widehat{L}_n(h)] \le \mathbb{E}\sup_h [\widehat{L}_n'(h) - \widehat{L}_n(h)] \\ &= \mathbb{E}\sup_h \frac{1}{n}\sum_i (\ell(h,z_i') - \ell(h,z_i)).\end{aligned}$$

对每个 $i$，由于 $z_i, z_i'$ 可交换，将第 $i$ 项乘以 $\epsilon_i$ 不改变整个族 $(\ell(h,z_i') - \ell(h,z_i))_{h,i}$ 的联合分布。故右侧等于 $\mathbb{E}\sup_h n^{-1}\sum_i \epsilon_i(\ell(h,z_i') - \ell(h,z_i))$，并至多为 $2\mathbb{E}\sup_h n^{-1}\sum_i \epsilon_i \ell(h,z_i)$。 □

**推论 5.7** (有限类别)**.** 若 $|\mathcal{H}| = m$，则 $\mathbb{E}Z \le 2\sqrt{2\log m/n}$，从而 $\mathbb{P}(Z \ge 2\sqrt{2\log m/n} + u) \le e^{-2nu^2}$。

证明. 以数据为条件，$X_h = n^{-1}\sum_i \epsilon_i \ell(h, z_i)$ 满足 $\mathbb{E}e^{\lambda X_h} = \prod_i \cosh(\lambda \ell(h, z_i)/n) \le e^{\lambda^2/(2n)}$。第 9–11 讲命题 2.2 的证明只用此界，因此 $\mathbb{E}\max_h X_h \le \sqrt{2\log m/n}$。 □

对无限类别，命题 5.6 的右侧可如 Dudley 不等式那样用链化约束，以 Rademacher 过程代替高斯过程：链化约束上确界的均值，McDiarmid 不等式约束其涨落。

## 5.3 Ville 不等式

**译注：** 有限停时的极限先控制 “存在某时刻达到阈值”。对 $\{\sup_n Z_n \ge a\}$，须先对任意 $b < a$ 应用达到界，利用 $\{\sup_n Z_n \ge a\} \subset \{\exists n : Z_n \ge b\}$，再令 $b \uparrow a$，以包含只逼近而不达到 $a$ 的路径。此为原证明的端点补充，定理仍有效。

**命题 5.8** (Ville)**.** 设 $Z$ 为非负上鞅。则对每个 $a > 0$，

$$\mathbb{P}\left(\sup_{n\ge 0} Z_n \ge a\right) \le \frac{\mathbb{E}Z_0}{a}.$$

证明. 令 $\tau = \min\{n : Z_n \ge a\}$。由推论 3.6 在有界时间 $\tau \wedge n$ 对上鞅 $Z$ 的结论，以及非负性，

$$\mathbb{E}Z_0 \ge \mathbb{E}Z_{\tau\wedge n} \ge \mathbb{E}[Z_{\tau\wedge n}\mathbf{1}_{\{\tau\le n\}}] \ge a\mathbb{P}(\tau \le n).$$

令 $n \to \infty$。 □

初始值 $Z_0 = 1$ 的非负上鞅在某个时刻超过 $a$ 的概率至多为 $1/a$，对所有停止规则一致成立；这就是序贯检验和置信序列背后的不等式。

## 5.4 Freedman 不等式

**译注：** 以下含 $c$ 的除法取 $c > 0$；$c = 0$ 的退化 / 极限情形须分开。加权噪声例及习题的 $\eta_{\max} = \max_k \eta_k$ 形式要求非负且有界的可预测步长（确定性 SGD 步长足够）和相应可积性；一般有符号步长须用 $\sup_k |\eta_k|$。若步长依赖当前噪声则未必是鞅差，例如 $\eta_k = \xi_k = \pm 1$ 时乘积恒为 1。$\eta = 0$ 等含除法的退化情况也不直接代入。

**引理 5.9.** 令 $\psi_c(\lambda) = (e^{\lambda c} - 1 - \lambda c)/c^2$，$\lambda > 0$。若 $\mathbb{E}_{k-1}\xi = 0$、$\xi \le c$ 且 $\sigma^2 = \mathbb{E}_{k-1}\xi^2$，则

$$\mathbb{E}_{k-1}e^{\lambda\xi} \le 1 + \psi_c(\lambda)\sigma^2 \le \exp(\psi_c(\lambda)\sigma^2).$$

证明. $h(x) = (e^x - 1 - x)/x^2$（$h(0) = 1/2$）在 $\mathbb{R}$ 上递增（习题 5.14），故当 $x \le \lambda c$ 时，$e^x \le 1 + x + x^2 h(\lambda c)$。取 $x = \lambda\xi$ 并用 $\lambda^2 h(\lambda c) = \psi_c(\lambda)$，得 $e^{\lambda\xi} \le 1 + \lambda\xi + \psi_c(\lambda)\xi^2$；取 $\mathbb{E}_{k-1}$（规则 (vi)）。 □

**推论 5.10.** 设 $M_0 = 0$ 且对所有 $k$ 有 $\xi_k \le c$。对每个 $\lambda > 0$，$Z_n = \exp(\lambda M_n - \psi_c(\lambda)\langle M\rangle_n)$ 是满足 $Z_0 = 1$ 的非负上鞅。

证明. $Z_n \le e^{\lambda nc}$ 有界，且 $\langle M\rangle_n$ 可预测，故由引理 5.9，$\mathbb{E}_{n-1}Z_n = Z_{n-1}e^{-\psi_c(\lambda)\sigma_n^2}\mathbb{E}_{n-1}e^{\lambda\xi_n} \le Z_{n-1}$。 □

**定理 5.11** (Freedman 不等式)**.** 设 $M_0 = 0$ 且对所有 $k$ 有 $\xi_k \le c$。则对所有 $u, v > 0$，

$$\mathbb{P}(\exists n : M_n \ge u \text{ 且} \langle M\rangle_n \le v) \le \exp\left(-\frac{u^2}{2(v + cu/3)}\right).$$

证明. 在该事件上，对相关的 $n$ 有 $Z_n \ge \exp(\lambda u - \psi_c(\lambda)v)$，故由 Ville 不等式，

$$\mathbb{P}(\cdots) \le \mathbb{P}\left(\sup_n Z_n \ge e^{\lambda u - \psi_c(\lambda)v}\right) \le \exp(-\lambda u + \psi_c(\lambda)v).$$

对 $0 < \lambda < 3/c$，$\psi_c(\lambda) \le \lambda^2/[2(1 - \lambda c/3)]$（习题 5.14）。取 $\lambda = u/(v + cu/3) < 3/c$，则 $1 - \lambda c/3 = v/(v + cu/3)$，指数为

$$-\frac{u}{v + cu/3}u + \frac{u^2}{(v + cu/3)^2}\frac{v + cu/3}{2} = -\frac{u^2}{2(v + cu/3)}.$$

□

定理 5.11 相对定理 5.2 有两个区别：该界依赖于实现的二次变差 $\langle M\rangle_n$ 而非 $\sum c_k^2$（当 $v \gg cu$ 时为高斯尾 $e^{-u^2/(2v)}$；独立和的 Bernstein 不等式是确定性 $\sigma_k^2$ 的情形），且它对所有 $n$ 同时成立。

**例 5.12** (依赖状态的噪声)**. 课堂演算**。令 $M_n = \sum_{k\le n}\eta_k\xi_k$，其中 $|\xi_k| \le c$，且对某个适应序列 $(\theta_k)$ 和满足 $s^2 \le c^2$ 的函数 $s$ 有 $\sigma_k^2 = s^2(\theta_{k-1})$。Azuma 给出

$$\mathbb{P}(M_n \ge u) \le \exp\left[-\frac{u^2}{2c^2\sum_{k\le n}\eta_k^2}\right].$$

Freedman 对每个 $v$ 给出

$$\mathbb{P}\left(\exists n : M_n \ge u,\ \sum_{k\le n}\eta_k^2 s^2(\theta_{k-1}) \le v\right) \le \exp\left(-\frac{u^2}{2(v + \eta_{\max}cu/3)}\right),$$

其中 $\eta_{\max} = \max_k \eta_k$。当路径 $(\theta_k)$ 将时间花在 $s$ 小的区域时，$v$ 可以取为远小于 $c^2\sum\eta_k^2$。对 SGD，这对应梯度噪声在极小点附近消失的区域（第 17 讲）。

**引用 · 高斯集中不等式**

设 $g \sim \mathcal{N}(0, I_d)$，$f : \mathbb{R}^d \to \mathbb{R}$ 对欧氏范数是 $L$-Lipschitz 的。则对所有 $u > 0$，$\mathbb{P}(f(g) - \mathbb{E}f(g) \ge u) \le e^{-u^2/(2L^2)}$。这是定理 5.3 的高斯对应物，用 $L$ 代替 $(\sum c_k^2)^{1/2}$，且无需有界差分假设；它可用第 11 讲的插值法证明。

## 第 15 讲习题

**习题 5.13** (A 类)**.** (a) 用常数 $e^{\lambda^2c^2/8}$ 证明引理 5.1：将 $\xi$ 写成端点 $a, a + c$ 的凸组合得到 $\mathbb{E}e^{\lambda\xi} \le e^{\phi(\lambda c)}$，其中 $\phi(t) = -pt + \log(1 - p + pe^t)$、$p = -a/c$，并证明 $\phi(0) = \phi'(0) = 0$、$\phi'' \le 1/4$。

(b) 对 $m$ 个固定预测器和 $[0,1]$ 中的损失，使用例 5.4 的并集界约束 $\mathbb{P}(\max_{j\le m}|\widehat{L}_n(h_j)-L(h_j)|\ge u)$，并与推论 5.7 比较。

**习题 5.14** (A 类)**.** (a) 证明 $h(x)=(e^x-1-x)/x^2$ 在 $\mathbb{R}$ 上递增。令 $k(x)=x^3h'(x)=(x-2)e^x+x+2$；则 $k'(x)=(x-1)e^x+1$、$k''(x)=xe^x$，故 $k'\ge 0$，$k$ 递增且 $k(0)=0$，并且在两条半直线上均有 $h'(x)=k(x)/x^3\ge 0$。

(b) 用 $k!\ge 2\cdot 3^{k-2}$，证明 $0<\lambda<3/c$ 时 $\psi_c(\lambda)\le \lambda^2/[2(1-\lambda c/3)]$。

**习题 5.15** (线性预测器, B 类)**.** 设 $x_1,\dots,x_n\in\mathbb{R}^d$、$\|x_i\|\le B$，且 $\mathcal{H}=\{x\mapsto\langle w,x\rangle:\|w\|\le 1\}$。证明

$$\mathbb{E}\sup_{\|w\|\le 1}\frac{1}{n}\sum_i\epsilon_i\langle w,x_i\rangle=\frac{1}{n}\mathbb{E}\left\|\sum_i\epsilon_i x_i\right\|\le\frac{1}{n}\left(\sum_i\|x_i\|^2\right)^{1/2}\le\frac{B}{\sqrt{n}},$$

并与例 5.5 和命题 5.6 结合，得到不依赖于 $d$ 的泛化界（可引用与 1-Lipschitz 损失复合不增加 Rademacher 复杂度）。

**习题 5.16** (Robbins–Monro 噪声, B 类)**.** 设 $|\xi_k|\le c$、$\eta_k=\eta/k$。对 $m\ge 2$，令 $M_n=\sum_{k=m}^n\eta_k\xi_k$，$n\ge m$。

(a) 证明每步由 $\eta c/m$ 约束，且对所有 $n$ 有 $\langle M\rangle_n\le\eta^2c^2/(m-1)$。

(b) 由定理 5.11 推得

$$\mathbb{P}\left(\exists n\ge m:\left|\sum_{k=m}^n\eta_k\xi_k\right|\ge u\right)\le 2\exp\left[-\frac{u^2}{2(\eta^2c^2/(m-1)+\eta cu/(3m))}\right].$$

(c) 与定理 3.10(ii) 比较。

**习题 5.17** (有界差分的两个例子，B 类)**.** (a) 令 $L_n$ 为 $[0,1]$ 中 $n$ 个独立同分布均匀点的最长递增子序列长度。证明 $L_n$ 的有界差分为 1，故 $\mathbb{P}(|L_n-\mathbb{E}L_n|\ge u)\le 2e^{-2u^2/n}$。（已知 $\mathbb{E}L_n\sim 2\sqrt{n}$，且涨落为 $n^{1/6}$ 量级。）

(b) 令 $B_n$ 为将 $n$ 个独立同分布、取值于 $[0,1]$ 的大小装箱所需的最少单位箱数。证明 $B_n$ 的有界差分为 1，并证明 $\sqrt{n}$ 量级的涨落确实会发生（将 $B_n$ 与各大小之和比较）。

**习题 5.18** (SGD 中 Freedman 与 Azuma 的比较，C 类)**.** 在习题 2.12 中取 $\eta_k=\eta/k$、$\eta>1/2$，以及依赖状态的噪声 $\epsilon_{k+1}=s(\theta_k)\zeta_{k+1}$，其中 $\zeta_k$ 为独立同分布的随机符号，$s(\theta)=\min(|\theta|,1)$。

(a) 证明对固定 $n$，噪声项

$$N_n=\sum_{k<n}w_{n,k}s(\theta_k)\zeta_{k+1}$$

是某个鞅的末值，其二次变差为 $\sum_{k<n}w_{n,k}^2s(\theta_k)^2$。

(b) 写出 $\mathbb{P}(|N_n|\ge u)$ 的 Azuma 和 Freedman 界。

(c) 证明在事件 $\{|\theta_k| \le \delta \text{ 对} k \ge n/2\}$ 上，Freedman 的方差项比 Azuma 的小一个 $\delta^2$ 量级的因子，并建立一个关于 $\theta_n \to 0$ 速率的自举论证。

**译注：** 原文该事件仅约束后半段状态；二次变差仍含早期项，仅凭此事件不能直接对整个和得到所述 $\delta^2$ 因子，还需控制早期贡献。此处保留原习题要求，不补造证明。

(d) 模拟并比较。

**习题 5.19** (算子范数，C 类)**.** 设 $M$ 为元素独立的 $N \times d$ 矩阵。

(a) 若元素位于 $[-1,1]$，证明 $\|M\|_{\mathrm{op}}$ 对每个元素的有界差分为 2，故 $\mathbb{P}(\|M\|_{\mathrm{op}} - \mathbb{E}\|M\|_{\mathrm{op}} \ge u) \le e^{-u^2/(2Nd)}$。将尺度 $\sqrt{Nd}$ 与 $\mathbb{E}\|M\|_{\mathrm{op}} \asymp \sqrt{N} + \sqrt{d}$（第 9–11 讲）比较，并检验按行分组元素给出相同尺度。

**译注：** 有界差分界成立，但仅独立且在 $[-1,1]$ 内，不能保证期望算子范数为 $\sqrt{N}+\sqrt{d}$ 量级。元素恒为 1 也独立，此时范数为 $\sqrt{Nd}$；恒为 0 则范数为 0。该均值尺度需另有中心化、非退化方差及合适系综假设，不能从本题有界性单独推出。

(b) 若元素独立同分布于 $\mathcal{N}(0,1)$，证明 $M \mapsto \|M\|_{\mathrm{op}}$ 关于 Frobenius 范数是 1-Lipschitz 的，并结合高斯集中方框及 $\mathbb{E}\|M\|_{\mathrm{op}} \le \sqrt{N} + \sqrt{d}$（第 11 讲），得到 $\mathbb{P}(\|M\|_{\mathrm{op}} \ge \sqrt{N} + \sqrt{d} + u) \le e^{-u^2/2}$。

(c) (b) 利用了 $\|\cdot\|_{\mathrm{op}}$ 的什么性质，而有界差分无法表达这一性质？（Talagrand 凸距离不等式是有界变量中能表达它的结果。）