

现代机器学习中的概率

ORF 526 课程材料译稿

第 1–2 讲：高斯分布（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 高斯分布及其线性结构

第 1、2 讲：高斯分布
定义、线性结构，以及作为投影的条件化。

纲要： $\varphi_X = \exp(\text{二次式}) \longrightarrow AX+b$ 为高斯随机向量 $\longrightarrow$ 不相关 $\Rightarrow$ 独立 $\longrightarrow$ 条件化是正交投影 $\longrightarrow$ 岭回归与去噪。
阅读指南： 带星号的节不在课堂讲授。这些节的内容完整，也属于考试范围，其中包含了大多数习题。习题分为 A 类（是否跟上讲课）、B 类（是否理解论证）和 C 类（需要一个思路；找到思路后就很短）。每周小测三类各出一题。

1.1 傅里叶分析中的几个事实

以下两个事实是标准结果，我们不予证明。傅里叶变换使用 $e^{-ix\cdot\xi}$，逆变换使用 $e^{+ix\cdot\xi}$。

命题 1.1 (傅里叶分析，引入的结果)**.** 对 $f \in L^1(\mathbb{R}^d)$，定义

$$\widehat{f}(\xi) = \int_{\mathbb{R}^d} f(x) e^{-ix\cdot\xi}\, dx, \qquad \xi \in \mathbb{R}^d.$$

则：

(i) **反演**。若 $f, \widehat{f} \in L^1(\mathbb{R}^d)$，则在 f 的每一个连续点处，

$$f(x) = (2\pi)^{-d} \int_{\mathbb{R}^d} \widehat{f}(\xi) e^{ix\cdot\xi}\, d\xi.$$

(ii) **导数**。若 $f, \partial_j f \in L^1$，则 $\widehat{\partial_j f}(\xi) = i\xi_j \widehat{f}(\xi)$；若 $x_j f \in L^1$，则 $\partial_{\xi_j} \widehat{f}(\xi) = \widehat{(-ix_j f)}(\xi)$。对 x 求导对应乘以 $i\xi_j$，乘以 x_j 对应 $i\partial_{\xi_j}$。

(iii) **等距性**。对 $f \in L^1 \cap L^2$，有 $\|\widehat{f}\|_{L^2}^2 = (2\pi)^d \|f\|_{L^2}^2$，且该变换可延拓为 $L^2(\mathbb{R}^d)$ 到自身的双射。

(iv) **唯一性**。设 W, W' 是 $\mathbb{R}^d$ 中的随机向量。若对每个 ξ 都有 $\mathbb{E}[e^{-iW\cdot\xi}] = \mathbb{E}[e^{-iW'\cdot\xi}]$，则 $W \overset{d}{=} W'$。若 h 满足 $\mathbb{E}|h(W)| < \infty$，且对每个 ξ 都有 $\mathbb{E}[h(W)e^{-iW\cdot\xi}] = 0$，则 $h(W) = 0$。

引入的结果：极限与期望的交换

设 Z, Z_n, Z_t 为随机变量。

(a) **控制收敛**。若 $Z_n \to Z$ 且 $|Z_n| \le W$，其中 $\mathbb{E}W < \infty$，则 $\mathbb{E}Z_n \to \mathbb{E}Z$。将 $\mathbb{E}$ 换成积分 $\int \cdot\, dx$，同样成立。

(b) **Fatou 引理**。若 $Z_n \ge 0$ 且 $Z_n \to Z$，则 $\mathbb{E}Z \le \liminf_n \mathbb{E}Z_n$。

(c) **求导**。若 $\lambda \mapsto Z_\lambda$ 的差商被同一个可积随机变量控制，则 $\frac{d}{d\lambda}\mathbb{E}[Z_\lambda] = \mathbb{E}[\partial_\lambda Z_\lambda]$。

(d) **Fubini 定理**。若 $\mathbb{E}\int |Z_t|\, dt < \infty$，则 $\mathbb{E}\int Z_t\, dt = \int \mathbb{E}[Z_t]\, dt$。

1.2 定义

定义 1.2 (特征函数). $\mathbb{R}^d$ 中随机向量 X 的特征函数为

$$\varphi_X(\xi) = \mathbb{E}[e^{-iX\cdot\xi}], \qquad \xi \in \mathbb{R}^d.$$

它对每个 X 都有定义，无须任何可积性假设，因为 $|e^{i\theta}| = 1$。直接可得 $\varphi_X(0) = 1$、$|\varphi_X(\xi)| \le 1$ 和 $\varphi_X(-\xi) = \overline{\varphi_X(\xi)}$。

定义 1.3 (高斯随机向量). 设 $\mu \in \mathbb{R}^d$，Σ 是对称的 $d \times d$ 矩阵。若 $\mathbb{R}^d$ 中的随机向量 X 满足

$$\varphi_X(\xi) = \exp\left(-i\mu\cdot\xi - \tfrac{1}{2}\xi^\top\Sigma\xi\right) \qquad \text{对每个}\xi \in \mathbb{R}^d,$$

则称 X 是均值为 μ、协方差为 Σ 的高斯随机向量，记作 $X \sim \mathcal{N}(\mu, \Sigma)$。

由命题 1.1(iv)，满足此条件的分布至多有一个；何时存在这样的分布将在下一节解决。

命题 1.4 (参数名副其实). 若 $X \sim \mathcal{N}(\mu, \Sigma)$，则 $\mathbb{E}|X|^2 < \infty$，且

$$\mathbb{E}[X_j] = \mu_j, \qquad \mathbb{E}[(X_j - \mu_j)(X_k - \mu_k)] = \Sigma_{jk}.$$

特别地，分布决定 (μ, Σ)，因此两个高斯随机向量同分布当且仅当它们的参数相同。

证明. 令 $\psi(\xi) = -i\mu\cdot\xi - \frac{1}{2}\xi^\top\Sigma\xi$，则 $\varphi_X = e^\psi$ 光滑，且

$$\begin{aligned}\partial_j\varphi_X|_{\xi=0} &= -i\mu_j,\\ \partial_j\partial_k\varphi_X|_{\xi=0} &= (\partial_j\partial_k\psi + \partial_j\psi\,\partial_k\psi)|_{\xi=0} = -\Sigma_{jk} - \mu_j\mu_k.\end{aligned}$$

二阶矩有限并非假设，而是由这种光滑性所迫。对 $h > 0$，

$$\frac{2\varphi_X(0) - \varphi_X(he_j) - \varphi_X(-he_j)}{h^2} = \mathbb{E}\left[\frac{2 - 2\cos(hX_j)}{h^2}\right],$$

当 $h \downarrow 0$ 时，左边收敛到 $-\partial_j^2\varphi_X(0) = \Sigma_{jj} + \mu_j^2$。被积函数非负并逐点收敛到 X_j^2，因此 Fatou 引理给出 $\mathbb{E}[X_j^2] \le \Sigma_{jj} + \mu_j^2 < \infty$。

有了 $\mathbb{E}|X|^2 < \infty$，$e^{-iX\cdot\xi}$ 的差商分别被 $|X_j|$ 和 $|X_jX_k|$ 控制，所以可在期望内求两次导数：$\partial_j\varphi_X(0) = -i\mathbb{E}[X_j]$，$\partial_j\partial_k\varphi_X(0) = -\mathbb{E}[X_jX_k]$。与上式比较即得 $\mathbb{E}[X_j] = \mu_j$ 和 $\mathbb{E}[X_jX_k] = \Sigma_{jk} + \mu_j\mu_k$。 □

定理 1.5 (仿射像). 若 $X \sim \mathcal{N}(\mu, \Sigma)$，$A \in \mathbb{R}^{m\times d}$ 且 $b \in \mathbb{R}^m$，则 $AX + b \sim \mathcal{N}(A\mu + b, A\Sigma A^\top)$。

证明. $\varphi_{AX+b}(\xi) = e^{-ib\cdot\xi}\mathbb{E}[e^{-iX\cdot(A^\top\xi)}] = e^{-ib\cdot\xi}\varphi_X(A^\top\xi)$。代入定义 1.3 并利用 $\mu\cdot A^\top\xi = (A\mu)\cdot\xi$，得到 $\exp(-i(A\mu+b)\cdot\xi - \frac{1}{2}\xi^\top A\Sigma A^\top\xi)$。 □

推论 1.6 (旋转不变性). 若 $X \sim \mathcal{N}(0, I_d)$ 且 $O \in O(d)$，则 $OX \overset{d}{=} X$。更一般地，对 $X \sim \mathcal{N}(0, \Sigma)$，恰当且仅当 $O\Sigma O^\top = \Sigma$ 时，$OX \overset{d}{=} X$。

证明. 定理 1.5 给出 $OX \sim \mathcal{N}(0, O\Sigma O^\top)$；由命题 1.4，这一分布等于 $\mathcal{N}(0, \Sigma)$ 当且仅当 $O\Sigma O^\top = \Sigma$。当 $\Sigma = I_d$ 时，这就是 $OO^\top = I_d$。 □

习题 1.9 表明，在坐标独立的分布中，此性质刻画了高斯分布。

推论 1.7 (逐个坐标)**.** $X \sim \mathcal{N}(\mu, \Sigma)$ 当且仅当对每个 $v \in \mathbb{R}^d$，都有 $v \cdot X \sim \mathcal{N}(v \cdot \mu, v^\top \Sigma v)$。

证明. 正向：在定理 1.5 中取 $A = v^\top$。反向：标量 $v \cdot X$ 的特征函数在 1 处的值为 $\mathbb{E}[e^{-iv \cdot X}] = \varphi_X(v)$；由假设，它等于 $\exp(-iv \cdot \mu - \frac{1}{2} v^\top \Sigma v)$，这就是定义 1.3。 □

习题 1.8 (A 类)**.** 设 $\mathbb{R}^2$ 上 $X \sim \mathcal{N}(\mu, \Sigma)$，其中 $\mu = (1, -1)$，$\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$。

(a) 显式写出 $\varphi_X(\xi)$，并按命题 1.4 中的方法通过求导求回 $\mathbb{E}[X_1 X_2]$。

(b) 用定理 1.5 求 $X_1 + X_2$、$X_1 - X_2$ 以及二元组 $(X_1 + X_2, X_1 - X_2)$ 的分布。前两个量是否独立？

(c) 现在令 Σ 为 $\mathbb{R}^2$ 上任意协方差矩阵。对哪些 Σ，$X_1 + X_2$ 与 $X_1 - X_2$ 独立？对哪些 Σ，存在 $v \neq 0$ 使 $v \cdot X$ 为常数？

习题 1.9 (C 类)**.** 设 $d \geq 2$，X 的坐标独立同分布，且对每个 $O \in O(d)$ 都有 $OX \overset{d}{=} X$。证明对某个 $c \geq 0$，$X \sim \mathcal{N}(0, cI_d)$。可以使用特征函数连续这一事实。

1.3 存在性

到目前为止，我们还没有展示出任何一个高斯随机向量。

引理 1.10. 设 g 在 $\mathbb{R}$ 上的密度为 $(2\pi)^{-1/2} e^{-x^2/2}$。则 $\mathbb{E}[e^{-i\lambda g}] = e^{-\lambda^2/2}$，即 $g \sim \mathcal{N}(0, 1)$。

证明. 令 $f(\lambda) = \mathbb{E}[e^{-i\lambda g}]$。$\lambda \mapsto e^{-i\lambda g}$ 的差商被 $|g|$ 控制，因此可以在期望内求导：

$$f'(\lambda) = \frac{-i}{\sqrt{2\pi}} \int_{\mathbb{R}} x e^{-i\lambda x} e^{-x^2/2} \, dx.$$

关键观察是 $x e^{-x^2/2} = -\frac{d}{dx} e^{-x^2/2}$；它将因子 x 变为导数，再通过分部积分移到另一因子上：

$$\begin{aligned} f'(\lambda) &= \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-i\lambda x} \frac{d}{dx}\left(e^{-x^2/2}\right) dx \\ &= \frac{-i}{\sqrt{2\pi}} \int_{\mathbb{R}} \left(\frac{d}{dx} e^{-i\lambda x}\right) e^{-x^2/2} \, dx = -\lambda f(\lambda). \end{aligned}$$

结合 $f(0) = 1$，这迫使 $f(\lambda) = e^{-\lambda^2/2}$。 □

注 1.11. 证明中使用了 $\mathbb{E}[g\, h(g)] = \mathbb{E}[h'(g)]$，其中 $h(x) = e^{-i\lambda x}$：对标准高斯而言，乘以 g 的作用类似于求导。这一事实将在第 4、5 讲再次出现。

若 $Z = (g_1, \ldots, g_d)$ 的各坐标为独立标准正态变量，则

$$\varphi_Z(\xi) = \prod_{j=1}^{d} \mathbb{E}[e^{-i\xi_j g_j}] = \prod_{j=1}^{d} e^{-\xi_j^2/2} = e^{-|\xi|^2/2},$$

所以 $Z \sim \mathcal{N}(0, I_d)$。

命题 1.12 (适定性)**.** 设 $\mu \in \mathbb{R}^d$，Σ 对称。存在满足定义 1.3 的随机向量，当且仅当 $\Sigma \succeq 0$；此时其分布唯一。若 $\Sigma = AA^\top$，可取 $X = AZ + \mu$，其中 $Z \sim \mathcal{N}(0, I_d)$。

证明. 若 $\Sigma \succeq 0$,将其分解为 $\Sigma = AA^\top$。对 $Z \sim \mathcal{N}(0, I_d)$ 应用定理 1.5,得 $AZ+\mu \sim \mathcal{N}(\mu, AA^\top) = \mathcal{N}(\mu, \Sigma)$。分布的唯一性来自命题 1.1(iv)。

反之，假设 $v^\top \Sigma v = -c$，其中 $c > 0$。沿 $\xi = sv$，定义 1.3 右侧的模为 $e^{s^2 c/2} \to \infty$，与 $|\varphi_X| \le 1$ 矛盾。 □

因此，$\mathbb{R}^d$ 上的高斯分布恰好由 $\mathbb{R}^d \times \mathrm{Sym}_{\ge 0}(\mathbb{R}^d)$ 编号。

例 1.13 (退化情形)**.** 取 $d = 2$、$\mu = 0$、$\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$；它是秩为 1 的半正定矩阵。由命题 1.12，分布 $\mathcal{N}(0, \Sigma)$ 存在，取 $A = \binom{1}{1}$ 可将其实现为 $X = (g, g)$。该分布支撑在一条直线上，因此没有密度，而定义 1.3 完全不受影响；若通过密度 $\propto e^{-\frac{1}{2}x^\top \Sigma^{-1} x}$ 定义，就会排除这种情形。

习题 1.14 (A 类)**.** 令 $\mathbb{R}^d$ 上 $f(x) = (2\pi)^{-d/2} e^{-|x|^2/2}$。证明 $\widehat{f}(\xi) = e^{-|\xi|^2/2}$，然后计算

$$(2\pi)^{-d} \int_{\mathbb{R}^d} e^{-|\xi|^2/2} e^{ix\cdot\xi}\, d\xi$$

并求回 f，以验证命题 1.1(i) 对这一对函数成立。由此说明标准高斯密度在相差因子 $(2\pi)^{d/2}$ 的意义下是傅里叶变换的不动点。

习题 1.15 (B 类)**.** 设 $\Sigma \succ 0$，写成 $\Sigma = AA^\top$，其中 A 可逆，令 $X = AZ + \mu$。

(a) 对 Z 的密度作变量替换，得到 $p_X(x) = (2\pi)^{-d/2} (\det \Sigma)^{-1/2} \exp[-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)]$，并检验结果与所选平方根 A 无关。

(b) 证明当 Σ 奇异时不存在密度：构造 $v \neq 0$ 使 $v \cdot (X - \mu) = 0$，并由此说明 X 落在一个维数小于 d 的仿射子空间上。

1.4 不相关与独立

定理 1.16. 设 (X, Y) 在 $\mathbb{R}^d \times \mathbb{R}^{d'}$ 中联合高斯，即拼接后的向量为高斯向量，且 $\mathrm{Cov}(X, Y) = 0$。则 $X \perp\!\!\!\perp Y$。

证明. 写 $\xi = (s, u)$。拼接向量的协方差为块对角矩阵，所以 $\xi^\top \Sigma \xi = s^\top \Sigma_{XX} s + u^\top \Sigma_{YY} u$，$\mu \cdot \xi = \mu_X \cdot s + \mu_Y \cdot u$。因此

$$\varphi_{(X,Y)}(s, u) = \varphi_X(s) \varphi_Y(u),$$

这正是由相互独立且分别满足 $X' \overset{d}{=} X$、$Y' \overset{d}{=} Y$ 的随机向量构成的二元组 (X', Y') 的特征函数。由命题 1.1(iv)，$(X, Y) \overset{d}{=} (X', Y')$，故 $X \perp\!\!\!\perp Y$。 □

在实际中失效的假设是联合高斯性，而不是边缘分布的高斯性。

例 1.17 (不相关、标准正态但不独立)**.** 设 $g \sim \mathcal{N}(0,1)$，ε 是独立的随机符号；令 $X = g$、$Y = \varepsilon g$。给定 $\varepsilon = \pm 1$ 时，$Y = \pm g \overset{d}{=} g$，故两个边缘分布均为标准正态。它们不相关，因为 $\mathbb{E}[XY] = \mathbb{E}[\varepsilon]\mathbb{E}[g^2] = 0$。而 $|X| = |Y|$ 恒成立，所以 X 决定 Y，只差一个符号。

对 ε 条件化并应用引理 1.10，

$$\varphi_{(X,Y)}(s,u) = \tfrac{1}{2}e^{-(s+u)^2/2} + \tfrac{1}{2}e^{-(s-u)^2/2},$$

这是两个高斯变换之和，而非 exp(二次式)。尽管每个坐标都满足定义 1.3，二元组却不满足。

习题 1.18 (B 类)**.** 继续例 1.17。

(a) 求 $X+Y$ 的分布，并通过找出一个原子说明它不是高斯分布。

(b) 推论 1.7 说，只要向量的每个线性泛函都是高斯的，该向量就是高斯向量。对任意 s,u 计算 $sX+uY$ 的分布，并说明为何没有矛盾。

(c) (X,Y) 在 $\mathbb{R}^2$ 上有密度吗?

1.5 * 熵，以及高斯分布为何使熵最大

本节不在课堂讲授。习题须在第 2 讲开始时交。

在 $\mathbb{R}^d$ 上所有具有给定均值和协方差 $\Sigma \succ 0$ 的分布中，高斯分布的微分熵最大。本节证明这一点；第 3 讲将用到这一结论。

若一个概率为 p 的事件发生，其惊异度 $s(p)$ 应满足 $s(1) = 0$ 和 $s(pq) = s(p) + s(q)$。代入 $p = e^{-u}$，后一个条件变为 $g(u+v) = g(u) + g(v)$，其中 $g(u) = s(e^{-u})$；它的连续解只有线性函数。因此 $s(p) = -c\log p$，对数的底决定单位，我们取 $c = 1$。

有限集上分布的熵是在观察之前的期望惊异度，

$$H(p) = \mathbb{E}[-\log p(X)] = -\sum_x p(x)\log p(x),$$

对于 $\mathbb{R}^d$ 上的密度 p，同一公式定义微分熵 $h(p) = -\int p\log p$。后者不是前者的另一种写法。

习题 1.19 (A 类)**.** (a) 计算正面概率为 q 的硬币的 H；画出其在 $q \in [0,1]$ 上的图像并求最大值所在。计算 n 个点上均匀分布的 H。

(b) 计算 $[0,a]$ 上均匀分布、速率为 λ 的指数分布及 $\mathcal{N}(0,\sigma^2)$ 的 h；最后一个应得到

$$\tfrac{1}{2}\log(2\pi e\sigma^2).$$

给出微分熵为负的分布，并说明离散熵为何不可能为负。

(c) 证明 $h(aX) = h(X) + \log|a|$，其中 $a \neq 0$。因此“长度的熵”并非一个定义良好的数，而 H 完全没有单位。

第 (c) 问表明 h 并不是表述最大化问题的合适量，于是相对于参考分布度量熵：对密度 p, q，相对熵为 $D(p\|q) = \int p\log(p/q)$。

习题 1.20 (B 类)**.** 证明 Gibbs 不等式：$D(p\|q)\ge 0$，等号成立当且仅当 $p=q$。对 $-\log$ 使用 Jensen 不等式。取 q 为均匀分布，推得其离散形式：n 个点上的任意分布都满足 $H(p)\le \log n$，等号仅对均匀分布成立。然后检验，当 X 被重新缩放时，$D(p\|q)$ 不变；h 则不同。

现在固定 μ 和 $\Sigma\succ 0$，令 q 为高斯密度，p 为具有该均值和协方差的任意密度。展开 $0\le D(p\|q)$ 得到 $0\le -h(p)-\int p\log q$；关键在第二项。

习题 1.21 (B 类)**.** 写出 $\log q$ 并观察它是 x 的二次多项式。由此推得 $\int p\log q$ 只通过均值和协方差依赖于 p，故等于 $\int q\log q=-h(q)$。证明 $h(p)\le h(q)$，等号仅在 $p=q$ 时成立，并检验 $h(q)=\frac12\log[(2\pi e)^d\det\Sigma]$。

这个论证只用到 $\log q$ 是二次式，因此 $\int p\log q$ 只通过前两阶矩了解 p。

习题 1.22 (C 类)**. 译注：**以下熵的加减及次可加性论证须在所涉微分熵有限或已明确良定义的条件下使用，不能对未定义的熵或 $\infty-\infty$ 作代数运算。仅有密度并不自动满足这一要求。

设 X,Y 独立同分布、对称且各有密度。证明

$$h\left(\frac{X+Y}{\sqrt2}\right)\ge h(X).$$

可以使用次可加性 $h(U,V)\le h(U)+h(V)$；这是对联合密度和其边缘密度之积应用 Gibbs 不等式所得。

习题 1.23 (C 类)**.** 固定 $S\subseteq\mathbb{R}^d$、S 上的函数 $T_1,\dots,T_k$ 和数 $c_1,\dots,c_k$。假设存在 $\lambda_1,\dots,\lambda_k$，使 $\exp(\sum_m\lambda_mT_m)$ 在 S 上的积分 Z 有限，因此 $q=Z^{-1}\exp(\sum_m\lambda_mT_m)$ 是一个密度，并且对每个 m 有 $\int qT_m=c_m$。证明在 S 上具有这些矩的密度中，q 唯一地使 h 最大。

将 $[0,a]$ 上的均匀分布、$[0,\infty)$ 上给定均值的指数分布和给定均值及协方差的 $\mathcal{N}(\mu,\Sigma)$ 作为特例求出。最后说明该假设确有作用：当 $S=\mathbb{R}$ 而只约束均值时，没有 λ 使 $e^{\lambda x}$ 可积，而且不存在最大化者——构造均值为 0 而 h 任意大的密度。

2 作为投影的条件化

问题：我们观测到 Y。对 X 的最佳猜测是什么？

2.1 期望是投影

设 $Z\sim\nu$ 是 $\mathbb{R}^k$ 中的随机向量，$f:\mathbb{R}^k\to\mathbb{R}$ 满足 $\mathbb{E}[f(Z)^2]<\infty$。

引理 2.1. $\mathbb{E}[f(Z)]=\arg\min_{c\in\mathbb{R}}\mathbb{E}[(f(Z)-c)^2]$，且最小值为 $\mathrm{Var}(f(Z))$。

证明. $\mathbb{E}[(f(Z)-c)^2]=\mathbb{E}[(f(Z)-\mathbb{E}f(Z))^2]+(\mathbb{E}f(Z)-c)^2$，因为交叉项为 $2(\mathbb{E}f(Z)-c)\mathbb{E}[f(Z)-\mathbb{E}f(Z)]=0$。 □

两种理解。第一，$\mathbb{E}[f(Z)]$ 是对 $f(Z)$ 的最佳确定性猜测。第二，写

$$L^2(\nu)=\{f:\mathbb{R}^k\to\mathbb{R}\mid\mathbb{E}[f(Z)^2]<\infty\},\qquad\langle f,g\rangle_\nu=\mathbb{E}[f(Z)g(Z)].$$

只要将满足 $\mathbb{E}[(f(Z)-g(Z))^2]=0$ 的 f,g 视为同一元素，这就是内积；下文均作此约定。我们使用 L^2 的标准性质：它是完备的，且每个闭子空间 H 都有唯一正交投影 Π_H，其特征为 $\Pi_H f\in H$ 且 $f-\Pi_H f\perp H$，并且它是 H 上 $\|f-h\|_\nu$ 的唯一极小元。

由于 $\mathbb{E}[(f(Z)-c)^2]=\|f-c\|_\nu^2$，引理 2.1 表明，当 H 为常数构成的空间时，$\mathbb{E}[f(Z)]=\Pi_H f$。

2.2 条件期望

设 $Z=(X,Y)$，其中 $X\in\mathbb{R}$、$Y\in\mathbb{R}^m$，记 Y 的分布为 ν_Y。由于 $\mathbb{E}[g(Y)^2]$ 在 ν 和 ν_Y 下计算得到相同的数，映射 $g\mapsto((x,y)\mapsto g(y))$ 将 $L^2(\nu_Y)$ 等同于 $L^2(\nu)$ 的一个闭子空间：只依赖于 Y 的函数空间。

定义 2.2 (条件期望)**.** $\mathbb{E}[X\mid Y]$ 是 X 到 $L^2(\nu_Y)$ 的正交投影。

按构造，它是 $L^2(\nu_Y)$ 的一个元素，即 Y 的函数。

引理 2.3. 对 $m\in L^2(\nu_Y)$，下列条件等价：

(i) $m=\mathbb{E}[X\mid Y]$；

(ii) 对每个 $g\in L^2(\nu_Y)$，$\mathbb{E}[(X-m(Y))g(Y)]=0$；

(iii) m 在 $g\in L^2(\nu_Y)$ 中使 $\mathbb{E}[(X-g(Y))^2]$ 最小。

此外，对每个 $g\in L^2(\nu_Y)$，

$$\mathbb{E}[(X-g(Y))^2]=\mathbb{E}[(X-\mathbb{E}[X\mid Y])^2]+\mathbb{E}[(\mathbb{E}[X\mid Y]-g(Y))^2]. \tag{1}$$

证明. 等价性来自 Π_H 的刻画；恒等式即勾股定理。 □

对 $X\in\mathbb{R}^p$，将该定义逐坐标应用。

2.3 塔式性质

命题 2.4. 设 $Z=(X,Y,V)$，则

$$\mathbb{E}[\mathbb{E}[X\mid Y,V]\mid Y]=\mathbb{E}[X\mid Y],\qquad\qquad \mathbb{E}[\mathbb{E}[X\mid Y]]=\mathbb{E}[X],$$

并且对有界的 g，$\mathbb{E}[g(Y)X\mid Y]=g(Y)\mathbb{E}[X\mid Y]$。

证明. $L^2(\nu_Y)\subseteq L^2(\nu_{(Y,V)})$，两者均为 $L^2(\nu)$ 的闭子空间。对嵌套的闭子空间 $H_1\subseteq H_2$，向量 $\Pi_{H_2}f-f$ 与 H_2 正交，从而与 H_1 正交，故 $\Pi_{H_1}\Pi_{H_2}f=\Pi_{H_1}f$。第一个恒等式对应上述一对子空间；第二个取 H_1 为 $H_2=L^2(\nu_Y)$ 中的常数空间。第三个等式由对每个 h 都有 $\mathbb{E}[(g(Y)X-g(Y)\mathbb{E}[X\mid Y])h(Y)]=\mathbb{E}[(X-\mathbb{E}[X\mid Y])(gh)(Y)]=0$ 得出。 □

推论 2.5 (全方差公式)**.** 记 $\operatorname{Var}(X\mid Y):=\mathbb{E}[(X-\mathbb{E}[X\mid Y])^2\mid Y]$，则

$$\operatorname{Var}(X)=\mathbb{E}[\operatorname{Var}(X\mid Y)]+\operatorname{Var}(\mathbb{E}[X\mid Y]).$$

译注： 本推论对一般 $X \in L^2$ 的残差平方仅保证属于 L^1，未必属于 L^2。平方的条件期望在此须用可积随机变量的 L^1 延拓，而非只用前文的正交投影定义；全方差恒等式仍成立。

证明. 在式 (1) 中取 $g \equiv \mathbb{E}X$，并对第一项使用 $\mathbb{E}[\mathbb{E}[\cdot \mid Y]] = \mathbb{E}[\cdot]$。 □

习题 2.6 (A 类)**.** 证明 $\operatorname{Var}(\mathbb{E}[X \mid Y]) \le \operatorname{Var}(X)$。刻画等号成立的情形，以及推论 2.5 中第一项承担全部方差的情形。

习题 2.7 (B 类)**.** 设 J 是一枚公平硬币，给定 J 时，X 相应服从 $\mathcal{N}(\pm 1, \sigma^2)$。取 $Y = J$，计算推论 2.5 的两项并与 $\operatorname{Var}(X)$ 核对。接着令 W 是 $X_1, \dots, X_n$ 的函数，且假设 $\mathbb{E}[U \mid X_1, \dots, X_n] = -W/n$。推得 $\mathbb{E}[U \mid W] = -W/n$，并指出所用性质。

2.4 高斯条件化

设 $(X, Y) \sim \mathcal{N}(0, \Sigma)$ 取值于 $\mathbb{R}^p \times \mathbb{R}^m$，协方差分块为 Σ_{XX}、$\Sigma_{XY} = \mathbb{E}[XY^\top]$、$\Sigma_{YY} = \mathbb{E}[YY^\top]$。

引理 2.8. 存在 $A \in \mathbb{R}^{p \times m}$ 使 $A\Sigma_{YY} = \Sigma_{XY}$；任意两个解满足 $A_1 Y = A_2 Y$；若 $\Sigma_{YY} \succ 0$，则解唯一且等于 $\Sigma_{XY}\Sigma_{YY}^{-1}$。

证明. 将方程转置，得到 $\Sigma_{YY}A^\top = \Sigma_{YX}$，它可解当且仅当 Σ_{YX} 的每一列 $\mathbb{E}[YX_i]$ 都属于 $\operatorname{range}\Sigma_{YY} = (\ker \Sigma_{YY})^\perp$。若 $v \in \ker \Sigma_{YY}$，则 $\operatorname{Var}(v \cdot Y) = v^\top \Sigma_{YY} v = 0$，故 $v \cdot Y = 0$，且 $v^\top \mathbb{E}[YX_i] = \mathbb{E}[(v \cdot Y)X_i] = 0$。若 $B = A_1 - A_2$，则 $\operatorname{Cov}(BY) = B\Sigma_{YY}B^\top = 0$，故 $BY = 0$。 □

定理 2.9. 令 A 如引理 2.8 所述，则向量 $X - AY$ 与 Y 独立，且 $\mathbb{E}[X \mid Y] = AY$。

证明. 引理 2.3(ii) 要求找到一个 Y 的函数，其残差与每个 $g(Y)$ 都不相关；残差与 Y 独立即可立即满足这一点。尝试 AY。$(X - AY, Y)$ 是 (X, Y) 的线性像，由定理 1.5 联合高斯，且

$$\operatorname{Cov}(X - AY, Y) = \Sigma_{XY} - A\Sigma_{YY} = 0,$$

故由定理 1.16，$X - AY \perp\!\!\!\perp Y$。于是对每个 $g \in L^2(\nu_Y)$，

$$\mathbb{E}[(X - AY)g(Y)] = \mathbb{E}[X - AY]\mathbb{E}[g(Y)] = 0.$$

□

定理 2.10. 令 $\Sigma_{X|Y} = \Sigma_{XX} - A\Sigma_{YX}$。则对每个 $\xi \in \mathbb{R}^p$，

$$\mathbb{E}[e^{-i\xi \cdot X} \mid Y] = \exp\left(-i\xi \cdot AY - \tfrac{1}{2}\xi^\top \Sigma_{X|Y}\xi\right),$$

即 $X \mid Y \sim \mathcal{N}(AY, \Sigma_{X|Y})$。特别地，$\operatorname{Cov}(X \mid Y) = \Sigma_{X|Y}$ 不依赖于 Y。

证明. 令 $R = X - AY$，它是高斯向量。利用 $A\Sigma_{YY} = \Sigma_{XY}$ 两次，

$$\operatorname{Cov}(R) = \Sigma_{XX} - A\Sigma_{YX} - \Sigma_{XY}A^\top + A\Sigma_{YY}A^\top = \Sigma_{X|Y},$$

故 $\mathbb{E}[e^{-i\xi \cdot R}] = e^{-\frac{1}{2}\xi^\top \Sigma_{X|Y}\xi}$。由定理 2.9，$R \perp\!\!\!\perp Y$，所以这个常数满足引理 2.3(ii) 对 $\mathbb{E}[e^{-i\xi \cdot R} \mid Y]$ 的刻画。写 $e^{-i\xi \cdot X} = e^{-i\xi \cdot AY} e^{-i\xi \cdot R}$，再由命题 2.4 将有界因子提出。 □

当 $\Sigma_{YY} \succ 0$ 时，

$$AY = \Sigma_{XY}\Sigma_{YY}^{-1}Y, \qquad \Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX},$$

后者是 Σ 中 Σ_{YY} 的 Schur 补。对非中心化的 (X, Y)，将 AY 替换为 $\mu_X + A(Y - \mu_Y)$。

2.5 贝叶斯线性模型与岭回归

译注： 本段高斯密度、噪声倒数及得分字典使用非退化噪声 $\sigma \neq 0$，通常取 $\sigma > 0$；$\lambda = \sigma^2/\tau^2$ 还要求 $\tau \neq 0$。所列 $\tau \to 0, \infty$ 是从正参数出发的极限，涉及无正则化逆矩阵时仍须满足相应秩条件。零噪声或零先验不能直接代入含除法的密度公式。

取

$$y = Hw + \sigma\varepsilon, \qquad w \sim \mathcal{N}(0, \tau^2 I_p), \qquad \varepsilon \sim \mathcal{N}(0, I_n) \text{ 且与} w \text{ 独立}.$$

(w, y) 是 (w, ε) 的线性像，故由定理 1.5 联合高斯，并有

$$\Sigma_{ww} = \tau^2 I, \qquad \Sigma_{wy} = \tau^2 H^\top, \qquad \Sigma_{yy} = \tau^2 HH^\top + \sigma^2 I.$$

定理 2.10 给出后验分布；用 $\tau^2 H^\top(\tau^2 HH^\top + \sigma^2 I)^{-1} = (H^\top H + \lambda I)^{-1} H^\top$ 化简：

命题 2.11. 令 $\lambda = \sigma^2/\tau^2$，则

$$\mathbb{E}[w \mid y] = (H^\top H + \lambda I)^{-1} H^\top y, \qquad \operatorname{Cov}(w \mid y) = \sigma^2 (H^\top H + \lambda I)^{-1}.$$

后验均值就是岭回归，其正则化参数为噪声方差与先验方差之比。以下习题须在第 3 讲开始时交。

习题 2.12 (A 类)**.** (a) 证明 $-\log p(y \mid w) = \frac{1}{2\sigma^2}\|y - Hw\|^2 + c$，其中 c 与 w 无关，因此最小二乘是最大似然。说明选择平方误差对噪声作了什么假设。

(b) 证明后验密度的最大化者为 $\widehat{w}_\lambda = \arg\min_w \{\|y - Hw\|^2 + \lambda\|w\|^2\}$。解释大的 λ，并计算 $\tau \to 0$ 和 $\tau \to \infty$ 时的极限。

习题 2.13 (B 类)**.** 计算 (w, y) 的联合协方差的三个分块，并应用定理 2.10 得出命题 2.11。然后验证 $\operatorname{Cov}(w \mid y)$ 不依赖于 y，并说明这对观测到出人意料的 y 的实验者意味着什么。

习题 2.14 (B 类)**.** 设 $Y \sim \mathcal{N}(0, 1)$，$X = Y^2 - 1$。证明 $\operatorname{Cov}(X, Y) = 0$，所以 X 到 $\operatorname{span}\{1, Y\}$ 的投影为 0，均方误差为 2。计算 $\mathbb{E}[X \mid Y]$ 及其误差。定理 2.9 的哪个假设不成立?

2.6 * 岭估计量的两种形式

本节不在课堂讲授。命题 2.11 求逆的是 $p \times p$ 矩阵，得到它的推导求逆的则是 $n \times n$ 矩阵。

习题 2.15 (C 类)**.** 证明当 $\lambda > 0$ 时，

$$(H^\top H + \lambda I_p)^{-1} H^\top = H^\top (HH^\top + \lambda I_n)^{-1},$$

并由此推得当 $p \gg n$ 时，岭回归的代价是 $O(n^3)$ 而非 $O(p^3)$。然后在 $n < p$ 且 H 行满秩时令 $\tau \to \infty$，证明后验均值收敛到 $H^\top(HH^\top)^{-1} y$，即 $Hw = y$ 的最小范数解。解释为何两种形式中只有一种能直接看出此极限。

译注： 这里的 $O(n^3)$ 与 $O(p^3)$ 比较已形成的稠密线性系统的分解代价。若从显式 $n \times p$ 矩阵 H 开始，通常形成 $HH^\top$ 还需 $O(n^2 p)$，再乘 $H^\top$ 需 $O(np)$；因此不是任意 $p \gg n$ 情形端到端均为 $O(n^3)$。

2.7 * 去噪就是条件化

本节不在课堂讲授。设 X 是 $\mathbb{R}^d$ 中满足 $\mathbb{E}|X|^2 < \infty$ 的随机向量，不假设其为高斯向量，并令

$$Y = X + \sigma\xi, \qquad \xi \sim \mathcal{N}(0, I_d) \text{ 且与} X \text{ 独立}.$$

则 Y 的密度为 $p_Y(y) = \mathbb{E}[\varphi_\sigma(y - X)]$，其中 φ_σ 是 $\mathcal{N}(0, \sigma^2 I_d)$ 的密度。函数 $\nabla \log p_Y$ 称为 Y 的得分函数。

命题 2.16 (Tweedie 公式)**.**

$$\mathbb{E}[X \mid Y] = Y + \sigma^2 \nabla \log p_Y(Y).$$

证明. 由引理 2.3(ii)，只需对每个光滑紧支撑函数 f 证明 $\mathbb{E}[\langle X - Y - \sigma^2 \nabla \log p_Y(Y), f(Y)\rangle] = 0$。

给定 X 时向量 ξ 是标准高斯向量，因此逐坐标使用 $\mathbb{E}[\eta F(\eta)] = \mathbb{E}[F'(\eta)]$（引理 1.10）得到

$$\mathbb{E}[\langle Y - X, f(Y)\rangle] = \sigma \mathbb{E}[\langle \xi, f(X + \sigma\xi)\rangle] = \sigma^2 \mathbb{E}[\nabla \cdot f(Y)].$$

对 y 分部积分，

$$\begin{aligned} \mathbb{E}[\nabla \cdot f(Y)] &= \int (\nabla \cdot f) p_Y \, dy = -\int \langle f(y), \nabla p_Y(y)\rangle \, dy \\ &= -\mathbb{E}[\langle f(Y), \nabla \log p_Y(Y)\rangle]. \end{aligned}$$

□

习题 2.17 (A 类)**.** 取 $X \sim \mathcal{N}(0, \tau^2 I_d)$。计算 p_Y 和 $\nabla \log p_Y$，并检验命题 2.16 给出 $\mathbb{E}[X \mid Y] = \frac{\tau^2}{\tau^2 + \sigma^2} Y$，与定理 2.9 一致。这两种推导中哪一个用到了 X 的高斯性?

习题 2.18 (B 类)**.** 证明 p_Y 光滑且 $\nabla p_Y(y) = \mathbb{E}[\nabla \varphi_\sigma(y - X)]$，并说明分部积分的边界项消失需要什么条件。然后证明在引理 2.3(ii) 中只用光滑紧支撑 f 作检验就足够。

习题 2.19 (C 类)**.** 去噪器是使 $\mathbb{E}|X - D(Y)|^2$ 在所有函数 $D : \mathbb{R}^d \to \mathbb{R}^d$ 上最小的 D。证明 D 和 $\nabla \log p_Y$ 显式地相互决定，并推得对数据对 $(X, X + \sigma\xi)$ 用最小二乘拟合去噪器，即可估计 Y 的分布的得分函数；这一过程既不需要 p_X，也不需要似然。



现代机器学习中的概率

ORF 526 课程材料译稿

第 1–2 讲习题解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

解答

编号与讲义一致。C 类习题的关键思路置于框中；掌握思路后其余部分是常规推导，这也正是分类的含义。

第 1–2 讲：定义、存在性与独立性（第 1.2–1.4 节）

1.8（A）

(a) $\mu\cdot\xi=\xi_1-\xi_2$ 且 $\xi^\top\Sigma\xi=2\xi_1^2+2\xi_1\xi_2+\xi_2^2$，故

$$\varphi_X(\xi)=\exp\!\left[-i(\xi_1-\xi_2)-\tfrac{1}{2}(2\xi_1^2+2\xi_1\xi_2+\xi_2^2)\right].$$

命题 1.4 给出 $\partial_1\partial_2\varphi_X(0)=-\Sigma_{12}-\mu_1\mu_2=-1+1=0=-\mathbb{E}[X_1X_2]$，故 $\mathbb{E}[X_1X_2]=0$——只有减去均值后才不相关。[1]

(b) 取 $B=\begin{pmatrix}1&1\\1&-1\end{pmatrix}$，定理 1.5 给出 $BX\sim\mathcal{N}((0,2),B\Sigma B^\top)$，其中 $B\Sigma B^\top=\begin{pmatrix}5&1\\1&1\end{pmatrix}$。故 $X_1+X_2\sim\mathcal{N}(0,5)$、$X_1-X_2\sim\mathcal{N}(2,1)$，且协方差为 $1\neq0$，因此不独立。

(c) $\mathrm{Cov}(X_1+X_2,X_1-X_2)=\Sigma_{11}-\Sigma_{22}$。由于二者联合高斯，由定理 1.16，独立等价于 $\Sigma_{11}=\Sigma_{22}$：不论相关性如何，方差相等即可。$v\cdot X$ 为常数当且仅当 $\mathrm{Var}(v\cdot X)=v^\top\Sigma v=0$，即 $v\in\ker\Sigma$，所以存在这样的非零 v 当且仅当 Σ 奇异。

1.9（C）

> 对变换应用不变性，把 $(\xi_1,\xi_2,0,\dots,0)$ 旋转到 $(\sqrt{\xi_1^2+\xi_2^2},0,\dots,0)$。独立性使 φ_X 成为乘积；旋转把此乘积变成关于 ξ^2 的 Cauchy 函数方程。

独立性给出 $\varphi_X(\xi)=\prod_j\varphi_1(\xi_j)$，其中 φ_1 是各坐标共同的变换。不变性对所有正交矩阵 O 给出 $\varphi_X(O^\top\xi)=\varphi_{OX}(\xi)=\varphi_X(\xi)$，故 φ_X 仅是 $|\xi|$ 的函数。取 $O=\mathrm{diag}(-1,1,\dots,1)$，得到 $X_1\overset{d}{=}-X_1$，故 φ_1 为实偶函数。

取 $\xi=(\xi_1,\xi_2,0,\dots,0)$，旋转到 $(r,0,\dots,0)$，其中 $r=\sqrt{\xi_1^2+\xi_2^2}$。由 $\varphi_1(0)=1$，两乘积相等：

$$\varphi_1(\xi_1)\varphi_1(\xi_2)=\varphi_1\!\left(\sqrt{\xi_1^2+\xi_2^2}\right).$$

令 $F(u)=\varphi_1(\sqrt{u})$，$u\geq0$，则 $F(u)F(v)=F(u+v)$、$F(0)=1$，且 F 连续。又 $F(u)=F(u/2)^2\geq0$；若某个 $F(u_0)=0$，则对每个 k 均有 $F(u_02^{-k})=0$，与连续性及 $F(0)=1$ 矛盾。因此 $F>0$，$\log F$ 连续且可加，故为线性函数，$F(u)=e^{-cu/2}$。由 $|F|\leq1$ 得 $c\geq0$，于是

$$\varphi_1(\xi)=e^{-c\xi^2/2},\qquad\varphi_X(\xi)=e^{-c|\xi|^2/2},\qquad X\sim\mathcal{N}(0,cI_d).$$

这里从未使用矩条件；方差最终作为常数 c 出现。$d\geq2$ 的作用在于：只有一个坐标时无从旋转，而 $O(1)=\{\pm1\}$ 只说明 X_1 对称。

---

[1] 此句按原文保留。本例 $\mathbb{E}[X_1X_2]=0$，但 $\mathrm{Cov}(X_1,X_2)=0-(1)(-1)=1$；减去均值后协方差仍为 1，故原文关于不相关的说法不成立。

1.14（A） 对 $Z\sim\mathcal{N}(0,I_d)$，

$$\widehat{f}(\xi)=\int f(x)e^{-ix\cdot\xi}\,dx=\mathbb{E}e^{-iZ\cdot\xi}=\prod_j e^{-\xi_j^2/2}=e^{-|\xi|^2/2},$$

这里最后一步用了 d 次引理 1.10。反演时每个坐标积分由同一引理给出

$$\int_{\mathbb{R}} e^{-\xi^2/2}e^{ix\xi}\,d\xi=\sqrt{2\pi}\,\mathbb{E}e^{-i(-x)g}=\sqrt{2\pi}e^{-x^2/2}.$$

将 d 个积分相乘并除以 $(2\pi)^d$，得到 $(2\pi)^{-d/2}e^{-|x|^2/2}=f(x)$。由于 $\widehat{f}=(2\pi)^{d/2}f$，标准高斯密度是变换的本征函数。

1.15（B）

(a) $Z=A^{-1}(X-\mu)$，故 $p_X(x)=p_Z(A^{-1}(x-\mu))|\det A|^{-1}$。由于 $\Sigma^{-1}=(AA^\top)^{-1}=A^{-\top}A^{-1}$，有 $|A^{-1}(x-\mu)|^2=(x-\mu)^\top\Sigma^{-1}(x-\mu)$，且 $|\det A|=(\det\Sigma)^{1/2}$。二者均仅依赖 Σ，故公式与所选平方根无关；具体地，任意两个平方根相差 $A'=AO$，O 正交，且 $|\det A'|=|\det A|$。

(b) 若 Σ 奇异，取非零 $v\in\ker\Sigma$。则 $\mathrm{Var}(v\cdot X)=v^\top\Sigma v=0$，故 X 位于超平面 $\{x:v\cdot x=v\cdot\mu\}$。任意密度在超平面上的积分为零，故 X 无密度。

1.18（B）

(a) $X+Y=(1+\epsilon)g$：$\epsilon=-1$ 时为零，$\epsilon=1$ 时为 $2g$，故为 δ_0 与 $\mathcal{N}(0,4)$ 的等权混合，在原点有质量 $1/2$ 的原子。高斯分布要么是点质量，要么有密度；该分布两者都不是。

(b) $sX+uY=(s+u\epsilon)g$ 是 $\mathcal{N}(0,(s+u)^2)$ 与 $\mathcal{N}(0,(s-u)^2)$ 的等权混合，在 $\xi=(s,u)$ 处的变换为 $\frac12e^{-(s+u)^2/2}+\frac12e^{-(s-u)^2/2}$。它仅在 $(s+u)^2=(s-u)^2$，即 $su=0$ 时为高斯。因此推论 1.7 的假设仅在两条坐标轴成立，这正是边缘分布高斯的陈述；离开坐标轴便不成立，故并不与该推论矛盾。

(c) 没有密度：(X,Y) 位于 $\{y=x\}\cup\{y=-x\}$，而密度在两条直线上的积分为零。

熵与高斯分布的极大熵性质（第 1.5* 节）

1.19（A）

(a) $H(q)=-q\log q-(1-q)\log(1-q)$ 关于 $q=1/2$ 对称，端点为零，在 $1/2$ 取最大值 $\log 2$。n 点上的均匀分布的熵为 $\log n$。

(b) 分别为 $\log a$、$1-\log\lambda$、$\frac12\log(2\pi e\sigma^2)$。当 $a<1$ 时 $[0,a]$ 上均匀分布的 $h=\log a<0$。离散熵非负，因为 $p\in(0,1]$ 时 $-p\log p\geq 0$；密度则可以超过 1，正是这一点打破了该结论。

(c) $p_Y(y)=|a|^{-1}p_X(y/a)$。换元 $x=y/a$ 得

$$h(Y)=-\int p_X(x)[\log p_X(x)-\log|a|]dx=h(X)+\log|a|.$$

1.20（B） 由 Jensen 不等式，$-D(p\|q)=\int p\log(q/p)\le\log\int q=0$，等号当且仅当 q/p 为常数，因而恒为 1。取 n 点上的均匀分布 $q\equiv 1/n$，则 $0\le D(p\|q)=-H(p)+\log n$，等号仅在 $p=q$ 时成立。变换 $X\mapsto aX$ 时两个密度获得相同因子 $|a|^{-1}$，且作相同换元，所以 $D(p\|q)$ 不变。

1.21（B） $\log q(x)=-\frac{d}{2}\log(2\pi)-\frac{1}{2}\log\det\Sigma-\frac{1}{2}(x-\mu)^\top\Sigma^{-1}(x-\mu)$ 是 x 的二次函数，因此 $\int p\log q$ 是 $\int p$、$\int x_i p$、$\int x_i x_j p$ 的固定线性函数。均值与协方差匹配给出 $\int p\log q=\int q\log q=-h(q)$，故 $0\le D(p\|q)=-h(p)+h(q)$。又 $\mathbb{E}[(X-\mu)^\top\Sigma^{-1}(X-\mu)]=\operatorname{tr}(\Sigma^{-1}\Sigma)=d$，所以 $h(q)=\frac{1}{2}\log((2\pi e)^d\det\Sigma)$。

1.22（C）

译注：以下熵的加减及次可加性论证须在所涉微分熵有限或已明确良定义的条件下使用，不能对未定义的熵或 $\infty-\infty$ 作代数运算。仅有密度并不自动满足这一要求。

> $(x,y)\mapsto((x+y)/\sqrt{2},(x-y)/\sqrt{2})$ 是正交变换，其雅可比为 1[a]，故保持联合微分熵。
>
> [a]原文如此表述。这个正交变换的行列式为 -1，绝对雅可比为 1；熵保持使用的是后者，故该结论不受影响。

令 $U=(X+Y)/\sqrt{2}$、$V=(X-Y)/\sqrt{2}$。由独立性 $h(U,V)=h(X,Y)=2h(X)$。次可加性 $h(U,V)\le h(U)+h(V)$ 来自对联合密度与边缘密度之积应用习题 1.20。由对称性 $(X,Y)\overset{d}{=}(X,-Y)$，故 $V\overset{d}{=}U$。连起来得 $2h(X)\le 2h(U)$。

1.23（C）

> 高斯情形的证明从未使用高斯性，而是使用了 $\log q$ 为受约束函数的仿射组合，因此 $\int p\log q$ 仅由约束确定。

$\log q=\sum_m\lambda_m T_m-\log Z$，所以对任何可行的 p，

$$0\le D(p\|q)=-h(p)-\sum_m\lambda_m c_m+\log Z,$$

后两项不依赖 p。取 $p=q$ 可知它们等于 $h(q)$；相减得到 $h(p)\le h(q)$，等号当且仅当 $p=q$。（无需假设 $h(p)$ 可积：$-\infty$ 时结论显然，$+\infty$ 则被 $D(p\|q)\ge 0$ 排除。）例子包括：$[0,a]$ 上无约束得到常数 q；$[0,\infty)$ 上 $T_1(x)=x$ 得到指数分布；T 为 x_i, x_ix_j 得到 $\mathcal{N}(\mu,\Sigma)$。

假设并非自动成立：在 $S=\mathbb{R}$ 上仅约束均值时，$e^{\lambda x}$ 不可积；这符合预期，因为每个 $\mathcal{N}(0,\sigma^2)$ 均可行，而 $h=\frac{1}{2}\log(2\pi e\sigma^2)\to\infty$。“$q$ 是密度”正是排除这一情况的条件；假设其存在就已经假设了实质内容。

塔式性质（第 2.3 节）

2.6（A） 推论 2.5 为 $\operatorname{Var}X=\mathbb{E}[\operatorname{Var}(X\mid Y)]+\operatorname{Var}(\mathbb{E}[X\mid Y])$，第一项非负。等号成立当且仅当 $\operatorname{Var}(X\mid Y)=0$，即 X 是 Y 的函数。全部方差恰好位于第一项当且仅当 $\mathbb{E}[X\mid Y]$ 为常数，

X 与 Y 独立时便是如此。

2.7（B） 给定 J 时，X 的均值为 ± 1、方差为 σ^2，故 $\mathrm{Var}(X \mid J) = \sigma^2$ 恒成立，$\mathbb{E}[\mathrm{Var}(X \mid J)] = \sigma^2$；而 $\mathbb{E}[X \mid J] = \pm 1$，$\mathrm{Var}(\mathbb{E}[X \mid J]) = 1$。总方差为 $\sigma^2 + 1$。直接计算得 $\mathbb{E}X = 0$，且

$$\mathbb{E}X^2 = \mathbb{E}[\mathbb{E}(X^2 \mid J)] = \mathbb{E}[\sigma^2 + 1] = \sigma^2 + 1.$$

第二部分中 W 是 $X_1, \ldots, X_n$ 的函数，因此以这些 X_i 为条件更精细；命题 2.4 给出

$$\mathbb{E}[V \mid W] = \mathbb{E}[\mathbb{E}[V \mid X_1, \ldots, X_n] \mid W] = \mathbb{E}[-W/n \mid W] = -W/n.$$

最后一步是因为 W 的函数在给定 W 下的条件期望就是自身。这一性质称为塔式性质。

贝叶斯线性模型与第 2.6*、2.7* 节

译注： 本段高斯密度、噪声倒数及得分字典使用非退化噪声 $\sigma \neq 0$，通常取 $\sigma > 0$；$\lambda = \sigma^2/\tau^2$ 还要求 $\tau \neq 0$。所列 $\tau \to 0, \infty$ 是从正参数出发的极限，涉及无正则化逆矩阵时仍须满足相应秩条件。零噪声或零先验不能直接代入含除法的密度公式。

2.12（A）

(a) $p(y \mid w) = (2\pi\sigma^2)^{-n/2} e^{-\|y - Hw\|^2/(2\sigma^2)}$，故 $-\log p = \|y - Hw\|^2/(2\sigma^2) + (n/2)\log(2\pi\sigma^2)$，关于 w 的最小值给出最小二乘拟合。选择平方误差就相当于断言噪声是高斯、同方差且在各观测之间独立；大多数选择平方误差的人并未作出这种断言，这正是要点。

(b) 后验密度正比于 $\exp[-\|y - Hw\|^2/(2\sigma^2) - \|w\|^2/(2\tau^2)]$，故其最大化等价于最小化 $\|y - Hw\|^2 + \lambda\|w\|^2$，其中 $\lambda = \sigma^2/\tau^2$。大的 λ 对应噪声较大的数据和较确信的先验，因而收缩强；$\tau \to 0$ 得 $\widehat{w} = 0$，$\tau \to \infty$ 得最小二乘。

2.13（B） (w, y) 是 (w, ϵ) 的线性像，因此联合高斯，其协方差块为

$$\Sigma_{ww} = \tau^2 I_p, \quad \Sigma_{wy} = \mathbb{E}[w(Hw + \sigma\epsilon)^\top] = \tau^2 H^\top, \quad \Sigma_{yy} = \tau^2 HH^\top + \sigma^2 I_n.$$

定理 2.10 直接给出两条公式。$\mathrm{Cov}(w \mid y)$ 不含 y：数据改变估计，却不改变不确定度。具体而言，出乎意料的 y 会移动后验均值，但误差条完全不变；这是高斯模型的特殊性质，通常不成立。

译注： 这里说的是给定模型和观测设置下，后验协方差不依赖实际观测值 y；不是说加入观测前后的不确定度相同。

2.14（B） $\mathrm{Cov}(X, Y) = \mathbb{E}[(Y^2 - 1)Y] = \mathbb{E}Y^3 = 0$，故最佳线性预测为零，误差为 $\mathrm{Var}\, X = \mathrm{Var}(Y^2) = 2$。这里 X 本身是 Y 的函数，所以 $\mathbb{E}[X \mid Y] = Y^2 - 1 = X$，误差为零。失效的假设是 (X, Y) 联合高斯——X 本身就不是高斯变量——因此定理 2.9 不适用，条件均值也不是线性的。

2.15（C）

> $H^\top(HH^\top+\lambda I_n)=(H^\top H+\lambda I_p)H^\top$：展开一行即可。再乘以两个逆矩阵。

两边均为 $H^\top HH^\top+\lambda H^\top$。左乘 $(H^\top H+\lambda I_p)^{-1}$，右乘 $(HH^\top+\lambda I_n)^{-1}$，便得到恒等式。右侧形式求逆的是 $n\times n$ 矩阵，因此计算成本为 $O(n^3)$；这就是核技巧，也解释了高斯过程回归为何可行。

译注：这里的 $O(n^3)$ 与 $O(p^3)$ 比较已形成的稠密线性系统的分解代价。若从显式 $n\times p$ 矩阵 H 开始，通常形成 $HH^\top$ 还需 $O(n^2p)$，再乘 $H^\top$ 需 $O(np)$；因此不是任意 $p\gg n$ 情形端到端均为 $O(n^3)$。

当 $\tau\to\infty$，有 $\lambda\to 0$；在 $H^\top(HH^\top+\lambda I_n)^{-1}y$ 中，极限是良性的，因为 $HH^\top$ 为 $n\times n$ 且可逆：

$$\mathbb{E}[w\mid y]\longrightarrow H^\top(HH^\top)^{-1}y,$$

这正是 $Hw=y$ 的最小范数解。另一形式的极限是 $0\cdot\infty$，这也是该题为 C 类而不是计算题的原因。

2.17（A） (X,ξ) 联合高斯，因此由第 1–2 讲定理 1.5，$Y=X+\sigma\xi\sim\mathcal{N}(0,(\tau^2+\sigma^2)I_d)$。故 $\log p_Y(y)=c-|y|^2/[2(\tau^2+\sigma^2)]$，$\nabla\log p_Y(y)=-y/(\tau^2+\sigma^2)$，命题 2.16 给出

$$\mathbb{E}[X\mid Y=y]=y-\frac{\sigma^2}{\tau^2+\sigma^2}y=\frac{\tau^2}{\tau^2+\sigma^2}y.$$

定理 2.9 给出 $\Sigma_{XY}\Sigma_{YY}^{-1}y=\tau^2 I((\tau^2+\sigma^2)I)^{-1}y$，结果相同。只有第二种推导使用了 X 的高斯性；第一种推导中，高斯性仅用于获得 p_Y 的闭式表达。

2.18（B） $p_Y(y)=\mathbb{E}[\phi_\sigma(y-X)]$。$\phi_\sigma$ 的每阶导数均有界，并且对于紧集中的 y，该界关于 X 一致；故控制收敛定理允许任意阶导数移入期望，$p_Y\in C^\infty$，且 $\nabla p_Y(y)=\mathbb{E}[\nabla\phi_\sigma(y-X)]$。

第二次分部积分 $\int\nabla f\,p_Y=-\int f\nabla p_Y$ 要求无穷远处 $fp_Y\to 0$。取光滑紧支撑 f 可使边界项直接消失，且这已足够：此类 f 在 $L^2(p_Y)$ 中稠密，因此与它们正交便与引理 2.3(ii) 的全部竞争者正交。这两步都可行是因为 Y 是与高斯分布的卷积；任意 Y 未必有密度，更不必说可微密度。

2.19（C）

> Tweedie 公式是字典：它给出最优去噪器与得分函数之间逐点的显式双射，因此得到任意一者就得到另一者。

由定义 2.2，在全部 D 上的最小二乘解为 $D(y)=\mathbb{E}[X\mid Y=y]$；命题 2.16 给出 $D(y)=y+\sigma^2\nabla\log p_Y(y)$，故

$$\nabla\log p_Y(y)=\frac{D(y)-y}{\sigma^2},$$

反之亦然。两个方向均未提及 p_X。

译注：最小二乘只确定 D 的 p_Y-几乎处处等价类；改变单个零测点的值不改变风险，却会破坏该点的得分等式。这里的逐点对应须选取自然版本 $D(y) = y + \sigma^2 \nabla \log p_Y(y)$ $(\sigma \neq 0)$，或将等式理解为几乎处处成立。

拟合 D 只需样本对 $(X, X + \sigma\xi)$，可通过对 X 的样本加噪声生成；既不需要 p_X 也不需要归一化常数。模块 II.11 在每个噪声水平 σ 使用得分函数以逆转加噪过程。



现代机器学习中的概率

ORF 526 课程材料译稿

第 3–4 讲：中心极限定理（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 高斯分布为何出现，以及通过替换证明中心极限定理

第 3、4 讲：中心极限定理
替换、Lindeberg 条件与 Stein 方法。

纲要： 最大熵 ⟶ 为什么是高斯分布 ⟶ 什么是依分布极限 ⟶ 每次替换一个求和项 ⟶ 中心极限定理与 Lindeberg 条件；
$\mathbb{E}[Wf(W)] = \mathbb{E}[f'(W)]$ ⟶ 向量与矩阵形式 ⟶ Stein 方程 ⟶ 带收敛速率的中心极限定理 ⟶ 对 Poisson 分布使用同一论证。
阅读指南： 带星号的节不在课堂讲授，其内容完整且属于考试范围。习题分为 A、B、C 三类，每周小测各出一题。每节末尾的方框列出需上交的习题；其余均为题库，供选做且属于考试范围，但无需上交。

问题： 在所有分布中，为什么出现的偏偏是高斯分布?

1.1 记号

全文中 $X_1, X_2, \ldots$ 独立同分布，均值为 0、方差为 1，并令

$$S_n := \frac{1}{\sqrt{n}} \sum_{i=1}^{n} X_i.$$

上述归一化使得对每个 n 都有 $\mathrm{Var}(S_n) = 1$。记 $g \sim \mathcal{N}(0,1)$，其分布为 γ。

来自第 1–2 讲的第 1.5* 节

对 $\mathbb{R}$ 上具有密度 p 的随机变量 X，微分熵为 $h(X) = -\int p \log p$，X 相对于 γ 的相对熵为 $D(X\|\gamma) = \int p \log(p/\varphi)$，其中 φ 是标准正态密度。两者都可能为 $+\infty$；X 无密度时，h 未定义。

1.2 “收敛到高斯分布”的含义

S_n 本身不收敛到一个随机变量；收敛的是它的分布，我们用函数对其进行检验。

定义 1.1 (依分布收敛)**.** 对 $\mathbb{R}^k$ 中的随机向量，$X_n \Rightarrow X$ 表示对每个有界连续的 $f : \mathbb{R}^k \to \mathbb{R}$，均有 $\mathbb{E}f(X_n) \to \mathbb{E}f(X)$。

分布函数在跳跃点不一定收敛：若 $X_n \equiv 1/n$ 且 $X \equiv 0$，则 $X_n \Rightarrow X$，但对每个 n 都有 $F_n(0) = 0$，而 $F(0) = 1$。

光滑函数 f 可以作 Taylor 展开，而 $1_{(-\infty,z]}$ 不能，因此下文的证明只用光滑函数检验。这已经足够。

引理 1.2. 假设对每个 $f \in C^3(\mathbb{R})$，只要 f, f', f'', f''' 均有界，就有 $\mathbb{E}f(X_n) \to \mathbb{E}f(X)$。则在 F_X 的每个连续点 z 处，$F_{X_n}(z) \to F_X(z)$。

证明. 固定这样的 z 和 $\delta>0$。取光滑函数 $\psi:\mathbb{R}\to[0,1]$，在 $(-\infty,0]$ 上为 1，在 $[1,\infty)$ 上为 0，并令

$$u_+(x)=\psi\left(\frac{x-z}{\delta}\right),\qquad u_-(x)=\psi\left(\frac{x-z+\delta}{\delta}\right).$$

两者均属于上述检验函数类，且

$$1_{(-\infty,z-\delta]}\le u_-\le 1_{(-\infty,z]}\le u_+\le 1_{(-\infty,z+\delta]}.$$

对 X_n 取期望并取极限，

$$F_X(z-\delta)\le \mathbb{E}u_-(X)=\lim_n \mathbb{E}u_-(X_n)\le \liminf_n F_{X_n}(z),$$
$$\limsup_n F_{X_n}(z)\le \lim_n \mathbb{E}u_+(X_n)=\mathbb{E}u_+(X)\le F_X(z+\delta).$$

令 $\delta\downarrow 0$，并利用 F_X 在 z 处的连续性。 □

对于光滑 f 的收敛速率不是概率的收敛速率；见第 2.3 节。

习题 1.3 (C 类)**.** 设 X_n, X 是 $\mathbb{R}^k$ 中的随机向量，且对每个直到三阶的导数均有界的 $f\in C^3(\mathbb{R}^k)$，都有 $\mathbb{E}f(X_n)\to\mathbb{E}f(X)$。证明 $X_n\Rightarrow X$。这样的 f 既非光滑函数，也不一定紧支撑；依次补救这两个缺陷，并注意假设本身已经限制了 X_n 在远处可以放置的概率质量。

1.3 直观答案

第 1–2 讲第 1.5* 节给出两个事实。第一，在固定方差时，高斯分布使熵最大：只要 $\mathrm{Var}(X)=1$，就有 $h(X)\le h(g)$。第二，对对称的独立同分布随机变量 X,Y，

$$h\left(\frac{X+Y}{\sqrt{2}}\right)\ge h(X),$$

因为 $(x,y)\mapsto((x+y)/\sqrt{2},(x-y)/\sqrt{2})$ 是正交变换，正交变换保持微分熵，而熵满足次可加性。

由于对两个独立副本有 $S_{2^k}=\frac{1}{\sqrt{2}}(S'_{2^{k-1}}+S''_{2^{k-1}})$，$h(S_{2^k})$ 随 k 增大而递增且从不超过 $h(g)$。所以它收敛，而最大化者是极限的唯一候选。

译注：以上保留原文的启发式说法。在单位有限方差且有密度的设定下，$h(X)\le h(g)<\infty$，故 h 不会为 $+\infty$，但可为 $-\infty$；一般熵运算仍需良定义。所示和差论证另用了对称性，仅中心化和单位方差并不够。即使熵单调有界，也不能单凭这一点辨认分布极限或证明中心极限定理；下面引用的定理是额外结果，此处未独立核验其文献证明。

1.4 熵形式的中心极限定理

定理 1.4 (Barron，1986)**.** 若对某个 m 有 $D(S_m\|\gamma)<\infty$，则 $D(S_n\|\gamma)\to 0$；等价地，$h(S_n)\to h(g)$。

定理 1.5 (Artstein–Ball–Barthe–Naor，2004)**.** $h(S_n)$ 随 n 递增，而不限于 n 为 2 的幂时。

我们不证明这两个定理。

例 1.6 (熵形式的中心极限定理无法说明抛硬币情形)**.** 令 $X_i = \pm 1$ 各以概率 $1/2$ 取值。则对每个 n，S_n 都支撑于有限集合，因此它没有密度，$h(S_n)$ 未定义，对每个 m, n 均有 $D(S_n\|\gamma) = \infty$。Barron 定理的假设始终不成立。

经典中心极限定理仍对 ± 1 成立，因此我们需要一个涵盖例 1.6 的证明。

1.5 Lindeberg 的替换论证

定理 1.7 (中心极限定理)**.** 进一步假设 $\mathbb{E}|X_1|^3 < \infty$。则对每个三阶导数有界的 $f \in C^3(\mathbb{R})$，

$$\big|\mathbb{E}f(S_n) - \mathbb{E}f(g)\big| \le \frac{\|f'''\|_\infty}{6\sqrt{n}}\big(\mathbb{E}|X_1|^3 + \mathbb{E}|g|^3\big).$$

证明. 取 $g_1, \dots, g_n$ 为独立同分布的标准高斯变量，且与各 X_i 独立，并构造插值：

$$Z_k = \frac{1}{\sqrt{n}}(g_1 + \cdots + g_k + X_{k+1} + \cdots + X_n), \qquad k = 0, \dots, n,$$

于是 $Z_0 = S_n$，$Z_n \sim \mathcal{N}(0,1)$。由望远镜求和，

$$\mathbb{E}f(S_n) - \mathbb{E}f(g) = \sum_{k=1}^{n}\big(\mathbb{E}f(Z_{k-1}) - \mathbb{E}f(Z_k)\big).$$

固定 k，记 $W_k = \frac{1}{\sqrt{n}}(g_1 + \cdots + g_{k-1} + X_{k+1} + \cdots + X_n)$，它与 X_k、g_k 均独立。于是 $Z_{k-1} = W_k + X_k/\sqrt{n}$、$Z_k = W_k + g_k/\sqrt{n}$。Taylor 定理给出

$$f(W_k + u) = f(W_k) + uf'(W_k) + \tfrac{u^2}{2}f''(W_k) + R(u), \qquad |R(u)| \le \frac{\|f'''\|_\infty}{6}|u|^3.$$

对两个展开取期望并相减。常数项抵消；一次项因 W_k 与 X_k, g_k 独立且后两者均值均为 0 而抵消；二次项因二者方差均为 1 而抵消。只剩余项：

$$\big|\mathbb{E}f(Z_{k-1}) - \mathbb{E}f(Z_k)\big| \le \frac{\|f'''\|_\infty}{6n^{3/2}}\big(\mathbb{E}|X_k|^3 + \mathbb{E}|g_k|^3\big).$$

对 n 项求和即得结论。 □

证明只使用了 Taylor 定理，特别地，它涵盖 $X_i = \pm 1$ 的情况。结合引理 1.2，对每个 z 有 $\mathbb{P}(S_n \le z) \to \Phi(z)$，其中 Φ 是标准正态分布函数。

经典论证——展开 $\varphi_{X_1}(t/\sqrt{n})$ 并取 n 次幂——在第 1.9* 节中给出。

1.6 证明实际需要什么

上述论证从未用到 X_i 同分布，也未用到它们是一维的：同样的替换配合多元 Taylor 展开给出多维中心极限定理。它确实用到的是，没有单个求和项占据很大一部分方差。

定义 1.8 (Lindeberg 条件)**.** 设 $\{X_{n,i}\}_{i \le k_n}$ 为逐行独立的三角阵列，且

$$\mathbb{E}X_{n,i} = 0, \qquad s_n^2 = \sum_{i \le k_n}\operatorname{Var}(X_{n,i}), \qquad k_n \to \infty, \qquad s_n \to \infty.$$

若对每个 $\varepsilon > 0$，

$$L_n(\varepsilon) := \frac{1}{s_n^2}\sum_i \mathbb{E}\big[X_{n,i}^2 \mathbf{1}_{\{|X_{n,i}| > \varepsilon s_n\}}\big] \longrightarrow 0,$$

则称该阵列满足 Lindeberg 条件。

统一作归一化：

$$Y_{n,i}=\frac{X_{n,i}}{s_n},\qquad \sigma_{n,i}^2=\operatorname{Var}(Y_{n,i}),\qquad T_n=\sum_{i\le k_n}Y_{n,i},$$

于是 $\sum_i \sigma_{n,i}^2=1$，且 $L_n(\varepsilon)=\sum_i \mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]$。

定理 1.9 (Lindeberg)**.** 在 Lindeberg 条件下，$T_n\Rightarrow\mathcal{N}(0,1)$。

证明. 设 $f\in C^3(\mathbb{R})$，f'' 与 f''' 有界。Taylor 定理展开到二阶和三阶，一致地对 w 给出

$$\begin{aligned} f(w+u)&=f(w)+uf'(w)+\tfrac{u^2}{2}f''(w)+R(u),\\ |R(u)|&\le \min\left(\frac{\|f'''\|_\infty}{6}|u|^3,\ \|f''\|_\infty u^2\right). \end{aligned}\tag{1}$$

第二个界由某个 $\theta\in(0,1)$ 对应的 $R(u)=\frac{u^2}{2}(f''(w+\theta u)-f''(w))$ 得到；它少一个 u 的幂，且不涉及 f'''。

在 ε 处分割 $Y_{n,i}$ 的二阶矩，对每个 i 和每个 $\varepsilon>0$，

$$\sigma_{n,i}^2=\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|\le\varepsilon\}}]+\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]\le\varepsilon^2+L_n(\varepsilon).\tag{2}$$

故对每个 ε 都有 $\limsup_n \max_i \sigma_{n,i}^2\le\varepsilon^2$，即 $\max_i\sigma_{n,i}\to 0$。

取 $g_{n,i}\sim\mathcal{N}(0,\sigma_{n,i}^2)$，彼此独立且与该阵列独立，于是 $\sum_i g_{n,i}\sim\mathcal{N}(0,1)$。仿照定理 1.7 逐项替换。令

$$W_{n,i}=g_{n,1}+\cdots+g_{n,i-1}+Y_{n,i+1}+\cdots+Y_{n,k_n},$$

它与 $Y_{n,i}$ 和 $g_{n,i}$ 均独立；望远镜求和给出

$$\bigl|\mathbb{E}f(T_n)-\mathbb{E}f(g)\bigr|\le\sum_i\bigl|\mathbb{E}f(W_{n,i}+Y_{n,i})-\mathbb{E}f(W_{n,i}+g_{n,i})\bigr|.$$

用式 (1) 展开两项。$Y_{n,i}$ 与 $g_{n,i}$ 的前两阶矩相同，且两者均与 $W_{n,i}$ 独立，因此常数、一次及二次项逐项抵消，只剩余项。在 Y 一侧，$|Y_{n,i}|\le\varepsilon$ 时使用三次界，$|Y_{n,i}|>\varepsilon$ 时使用二次界：

$$\begin{aligned}\sum_i\mathbb{E}|R(Y_{n,i})|&\le\frac{\|f'''\|_\infty}{6}\varepsilon\sum_i\mathbb{E}[Y_{n,i}^2]+\|f''\|_\infty\sum_i\mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\varepsilon\}}]\\&=\frac{\|f'''\|_\infty}{6}\varepsilon+\|f''\|_\infty L_n(\varepsilon).\end{aligned}$$

高斯一侧无需截断：$\mathbb{E}|g_{n,i}|^3=2\sqrt{2/\pi}\,\sigma_{n,i}^3$，且 $\sum_i\sigma_{n,i}^3\le\max_i\sigma_{n,i}$，所以

$$\sum_i\mathbb{E}|R(g_{n,i})|\le\frac{\|f'''\|_\infty}{3}\sqrt{\frac{2}{\pi}}\max_i\sigma_{n,i}.$$

将两边相加并令 $n\to\infty$：由假设 $L_n(\varepsilon)\to 0$，由式 (2) 有 $\max_i\sigma_{n,i}\to 0$，故对每个 $\varepsilon>0$，

$$\limsup_{n\to\infty}\bigl|\mathbb{E}f(T_n)-\mathbb{E}f(g)\bigr|\le\frac{\|f'''\|_\infty}{6}\varepsilon.$$

因此左边为 0。引理 1.2 将其转为依分布收敛。 □

注 1.10 (Feller 条件)**.** 若

$$\max_{i\le k_n}\frac{\operatorname{Var}(X_{n,i})}{s_n^2}=\max_{i\le k_n}\sigma_{n,i}^2\longrightarrow 0,$$

则称该阵列满足 Feller 条件。以下三个精确陈述将它与定义 1.8 联系起来。

(a) Lindeberg 条件蕴含 Feller 条件。这正是式 (2)；也是上面证明中除 $L_n(\varepsilon)\to 0$ 以外唯一使用的条件。

(b) 该蕴含是严格的：习题 1.14 给出满足 Feller 条件但不满足 Lindeberg 条件的阵列。

(c) 逆命题，只作陈述不证明：若 Feller 条件成立且 $T_n\Rightarrow\mathcal{N}(0,1)$，则 Lindeberg 条件成立。

结合定理 1.9，(c) 表明在 Feller 条件下 Lindeberg 条件等价于中心极限定理。这两项合称 Lindeberg–Feller 定理。

注 1.11 (Lyapunov 条件)**.** 实践中常检验一个较粗的条件：若对某个 $\delta>0$，

$$\frac{1}{s_n^{2+\delta}}\sum_{i}\mathbb{E}|X_{n,i}|^{2+\delta}\longrightarrow 0,$$

则 Lindeberg 条件成立：在 $\{|X_{n,i}|>\varepsilon s_n\}$ 上可写 $X_{n,i}^2\le |X_{n,i}|^{2+\delta}/(\varepsilon s_n)^{\delta}$。对独立同分布噪声的加权和 $X_{n,i}=a_{n,i}\xi_i$，若 $\mathbb{E}|\xi_1|^3<\infty$，这给出

$$L_n(\varepsilon)\le\frac{\mathbb{E}|\xi_1|^3}{\varepsilon}\left(\frac{\|a_n\|_3}{\|a_n\|_2}\right)^3,$$

所以只要 $\|a_n\|_3/\|a_n\|_2\to 0$，该和渐近高斯。这一条件失效恰好对应有限个坐标占据 $\|a_n\|_2^2$ 的固定份额。

译注：这条所印定量界使用 $\mathbb{E}\xi_i=0$、$\operatorname{Var}\xi_i=1$。若方差为 $v\in(0,\infty)$，右侧须另除以 $v^{3/2}$（并使用中心化三阶绝对矩）；否则重缩放 ξ_i 会改变右侧而不改变归一化后的 L_n。零方差情形须另行处理。

Lindeberg 条件区分了两个区域：许多小贡献给出高斯分布，少数稀有贡献给出 Poisson 分布。第 1.9^{*} 节计算边界两侧；第 2.4 节证明 Poisson 情形并给出速率。

注 1.12 (极限是普适的，速率不是)**.** 通过模拟得到 S_{30} 与 $\mathcal{N}(0,1)$ 的 Kolmogorov–Smirnov 距离：均匀分布为 0.0014，指数分布为 0.025，±1 为 0.073。极限不依赖于 X_1 的分布；速度则依赖，格点型求和项最慢。

习题 1.13 (A 类)**.** 设 $X_1,X_2,\dots$ 独立同分布，均值为 0、方差 $\sigma^2\in(0,\infty)$，对 $i\le n$ 令 $X_{n,i}=X_i$。证明 $L_n(\varepsilon)=\sigma^{-2}\mathbb{E}[X_1^2\mathbf{1}_{\{|X_1|>\varepsilon\sigma\sqrt{n}\}}]$ 且它趋于 0。使用控制收敛，控制变量为 X_1^2。由此说明定理 1.9 包含不要求三阶矩的定理 1.7。

习题 1.14 (C 类)**.** 设 $X_{n,i}$ $(i\le n)$ 独立，各以概率 $\frac12(1-\frac1n)$ 取值 ±1，各以概率 $\frac{1}{2n}$ 取值 $\pm\sqrt{n}$。证明 $s_n^2=2n-1$，Feller 条件成立，并且对每个 $\varepsilon\le 1/\sqrt{2}$ 有 $L_n(\varepsilon)\to\frac12$。接着计算 $\lim_n\varphi_{T_n}(t)$ 并辨认极限分布。注 1.10(c) 在计算之前就说明极限不可能为 $\mathcal{N}(0,1)$。一半方差位于 ±1，一半位于稀有的 $\pm\sqrt{n}$。

1.7 纪录，以及随机搜索为何趋于平台

定义 1.8 中 $s_n \to \infty$ 的假设有以下推论。

引理 1.15. 若定义 1.8 中的阵列一致有界，即对所有 n, i 都有 $|X_{n,i}| \le C$，则 Lindeberg 条件成立。

证明. 固定 $\varepsilon > 0$。由于 $s_n \to \infty$，当 n 充分大时 $\varepsilon s_n > C$，此时对每个 i，事件 $\{|X_{n,i}| > \varepsilon s_n\}$ 均为空，因此 $L_n(\varepsilon) = 0$。 □

下面的阵列不是同分布求和项之和的重新缩放。设 $X_1, X_2, \dots$ 独立同分布且分布连续，故当 $i \neq j$ 时 $\mathbb{P}(X_i = X_j) = 0$，并令

$$B_i = \mathbf{1}\{X_i > \max(X_1, \dots, X_{i-1})\}, \qquad B_1 = 1,$$

于是 $R_n = \sum_{i \le n} B_i$ 计数前 n 个观测中的纪录，即迄今最大值被改进的次数。

引理 1.16 (Rényi)**.** $B_1, \dots, B_n$ 独立，且 $\mathbb{P}(B_i = 1) = 1/i$。

证明. 两个秩向量。令

$$r_i = \#\{j \le n : X_j \le X_i\}, \qquad \rho_i = \#\{j \le i : X_j \le X_i\},$$

于是 $r \in S_n$ 记录整个样本的相对次序，ρ_i 只记录 X_i 在前 i 个观测中的秩，且 $B_i = \mathbf{1}\{\rho_i = i\}$。注意 $\rho_i \in \{1, \dots, i\}$，故 ρ 取值于

$$C = \{1\} \times \{1, 2\} \times \cdots \times \{1, \dots, n\}.$$

（例如 $n = 3$ 且 $X_2 < X_3 < X_1$ 时，$r = (3, 1, 2)$，$\rho = (1, 1, 2)$，只有 X_1 是纪录。）

第一步：r 在 S_n 上均匀。各 X_i 独立同分布且相等的概率为 0，所以置换样本不改变其分布；因此对所有 $\pi \in S_n$，$\mathbb{P}(r = \pi)$ 相同，而这样的置换共有 $n!$ 个。

第二步：$r \mapsto \rho$ 是 $S_n \to C$ 的双射。两集合都有 $n!$ 个元素，故只需证明映射单射，即可由 ρ 恢复 r。对 n 归纳：由于 $\rho_n = r_n$，最后一个观测在次序中的位置已知。将其删除后，剩下 $X_1, \dots, X_{n-1}$，其秩向量映为 $(\rho_1, \dots, \rho_{n-1})$，因为每个 $i < n$ 的 ρ_i 仅涉及前 i 个观测，故由归纳假设确定。将 X_n 按秩 ρ_n 重新插入即可恢复 r。

第三步：双射将均匀分布映成均匀分布，因此 ρ 在 C 上均匀。乘积集上的均匀分布恰好意味着坐标独立且各自均匀：$\rho_1, \dots, \rho_n$ 独立，ρ_i 在 $\{1, \dots, i\}$ 上均匀。所以 $B_i = \mathbf{1}\{\rho_i = i\}$ 独立，且 $\mathbb{P}(B_i = 1) = 1/i$。 □

定理 1.17 (纪录)**.** 令 $H_n = \sum_{i \le n} 1/i$，$s_n^2 = H_n - \sum_{i \le n} 1/i^2$，则

$$\frac{R_n - H_n}{s_n} \Rightarrow \mathcal{N}(0, 1).$$

证明. 对阵列 $X_{n,i} = B_i - 1/i$ $(i \le n)$ 应用定理 1.9。由引理 1.16，该阵列独立且中心化，$\mathrm{Var}(X_{n,i}) = \frac{1}{i}(1 - \frac{1}{i})$，因而 s_n^2 如上。由于 $s_n^2 \ge H_n - \pi^2/6 \to \infty$ 且 $|X_{n,i}| \le 1$，引理 1.15 给出 Lindeberg 条件。 □

各方差 $\frac{1}{i}(1-\frac{1}{i})$ 彼此不可比，且 s_n 按 $\sqrt{\log n}$ 而非 $\sqrt{n}$ 的量级增长，因此没有任何重新缩放可将 R_n 化为某个 S_m。

注 1.18 (两种情形中的 Bernoulli 阵列)**.** 第 1.6 节的两种情形都是独立 Bernoulli 变量的阵列，只是方差不同。对 $B_{n,i}\sim\text{Bernoulli}(\lambda/n)$ $(i\le n)$，总方差 $\lambda(1-\lambda/n)$ 保持有界，定义 1.8 完全不适用，极限为 Poisson(λ)。对 $B_i\sim\text{Bernoulli}(1/i)$，总方差发散，极限为高斯。假设 $s_n\to\infty$ 区分了两者。

注 1.19 (随机搜索)**.** 对独立抽取的 n 个超参数配置评分，并保留迄今最佳者。当前最佳值被改进的次数正是 R_n，因此其期望为 H_n，涨落量级为 $\sqrt{\log n}$：$\mathbb{E}R_{100}=5.19$、$\mathbb{E}R_{10^4}=9.79$。n 增加一百倍使期望改进次数增加 $\log 100=4.6$。

注 1.20 (一个缓慢的定理)**.** 有效样本量是 $s_n^2\approx\log n$，而非 n，因此误差应为 $1/s_n$ 的量级。$(R_n-H_n)/s_n$ 与 $\mathcal{N}(0,1)$ 的精确 Kolmogorov–Smirnov 距离如下：

n	10^2	10^3	10^4	10^5
KS	0.131	0.106	0.089	0.080
$1/s_n$	0.53	0.41	0.35	0.31

要使误差减半，需将 n 提高到四次方。与注 1.12 类似，R_n 也取格点值。

习题 1.21 (A 类)**.** 设 $B_{n,i}\sim\text{Bernoulli}(p_{n,i})$ $(i\le k_n)$ 相互独立，令 $\sigma_n^2=\sum_i p_{n,i}(1-p_{n,i})$。证明若 $\sigma_n\to\infty$，则

$$\frac{1}{\sigma_n}\sum_i(B_{n,i}-p_{n,i})\Rightarrow\mathcal{N}(0,1).$$

使用引理 1.15，一行即可。注 1.18 中 $p_{n,i}=\lambda/n$ 的阵列在何处不满足假设，其极限又是什么？

习题 1.22 (B 类)**.** 由定理 1.17 推得 $(R_n-\log n)/\sqrt{\log n}\Rightarrow\mathcal{N}(0,1)$。先证明这个工具：若 $Z_n\Rightarrow Z$、$\sup_n\mathbb{E}Z_n^2<\infty$，且确定性数列 $a_n\to1$、$b_n\to0$，则 $a_nZ_n+b_n\Rightarrow Z$。对有界一致连续的 f，在 $|Z_n|\le M$ 处分割，并将远处部分用 $2\|f\|_\infty\mathbb{P}(|Z_n|>M)\le 2\|f\|_\infty M^{-2}\sup_n\mathbb{E}Z_n^2$ 控制。再使用 $H_n-\log n\to\gamma$ 和 $s_n^2/\log n\to1$。为何仅靠引理 1.2 不够？

习题 1.23 (B 类)**.** 依次插入 $1,2,\dots,n$，以循环形式构造 $[n]$ 上的均匀随机置换：元素 i 以概率 $1/i$ 开启一个新循环；否则把它放在已有 $i-1$ 个元素之一的正后方，每种位置概率均为 $1/i$。证明每个置换都来自唯一的选择序列，而每个序列的概率均为 $1/n!$，因此该构造是均匀的。推得循环数 K_n 与 $\sum_{i\le n}\text{Bernoulli}(1/i)$ 同分布，其中各求和项独立，因而

$$\frac{K_n-\log n}{\sqrt{\log n}}\Rightarrow\mathcal{N}(0,1).$$

这就是 Gončarov 定理，该双射与引理 1.16 中的计数论证相同。

1.8 * 初始化时的宽网络

本节不在课堂讲授。固定非线性函数 $\sigma:\mathbb{R}\to\mathbb{R}$，令

$$f_m(x)=\frac{1}{\sqrt{m}}\sum_{j=1}^{m}a_j\sigma(\langle w_j,x\rangle),\qquad x\in\mathbb{R}^d,$$

其中 $w_1,\dots,w_m$ 是 $\mathbb{R}^d$ 中独立同分布的随机向量，$a_1,\dots,a_m$ 独立同分布，均值为 0、方差为 σ_a^2，且与各 w_j 独立。这是初始化时宽度为 m 的单隐层网络，归一化使 $\operatorname{Var} f_m(x)$ 不随宽度增长而改变。

命题 1.24. 固定有限个输入 $x_1,\dots,x_k$，且对每个 i 假设 $\mathbb{E}[\sigma(\langle w,x_i\rangle)^2]<\infty$。则

$$(f_m(x_1),\dots,f_m(x_k))\Rightarrow\mathcal{N}(0,K),\qquad K(x,x')=\sigma_a^2\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)].$$

习题 1.25 (B 类)**.** 证明这一命题。令 $V_j=(a_j\sigma(\langle w_j,x_1\rangle),\dots,a_j\sigma(\langle w_j,x_k\rangle))\in\mathbb{R}^k$，并将 $(f_m(x_1),\dots,f_m(x_k))$ 识别为 $m^{-1/2}\sum_j V_j$。检验 $\mathbb{E}V_j=0$ 和 $\operatorname{Cov}(V_j)=K$，分别指出何处用到 a_j 与 w_j 的独立性。然后或者引用多维中心极限定理，或者对每个固定的 $v\in\mathbb{R}^k$ 将定理 1.7 应用于标量 $\langle v,V_j\rangle$，读出 $\mathbb{R}^k$ 上变换的收敛，并用引理 1.29 完成证明。说明两条路径中哪一条需要三阶矩。

习题 1.26 (A 类)**.** 证明对任意满足 $\mathbb{E}[\sigma(\langle w,x_i\rangle)^2]<\infty$ 的 σ，K 是合法的协方差，即对每个 $v\in\mathbb{R}^k$，$\sum_{i,l}v_iv_lK(x_i,x_l)\ge 0$。一行即可。

极限为高斯，无论 σ 及权重的分布是什么；它们只通过 K 起作用。

习题 1.27 (C 类)**.** 设 $\sigma=\max(\cdot,0)$，$w\sim\mathcal{N}(0,I_d)$。对非零的 x,x'，令 $\theta=\angle(x,x')$，证明

$$\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)]=\frac{\|x\|\,\|x'\|}{2\pi}\big(\sin\theta+(\pi-\theta)\cos\theta\big).$$

当 $\theta=0$ 时与 $\mathbb{E}[\max(0,g)^2]$ 核对；当 $\theta=\pi/2$ 时与独立性核对。这就是反余弦核。

注 1.28. 命题 1.24 涉及有限个输入。对 $\mathbb{R}^d$ 的每个有限子集都同时成立，正是称该极限为核 K 的高斯过程的含义——见第 9 讲。对数据作条件化就是第 1–2 讲的定理 2.9，其中 Σ 换为核矩阵；因此，以精确贝叶斯推断拟合的无限宽网络是核为 K 的核回归。有限宽度时 f_m 不是高斯的，差异大小是关于命题 1.24 收敛速率的问题，第 4 讲将给出答案。

译注： 原文有限宽度非高斯的说法描述一般随机隐特征情形，并非所有允许模型。若 $w_j\equiv w_0$ 为确定值，且各 a_j 为独立高斯，则任意有限个输入的输出在每个有限 m 已联合高斯（ReLU 也如此）。上面的过程极限仍按有限维分布理解。

1.9 * 我们没有给出的证明

本节不在课堂讲授。特征函数将和变成积，而 n 个近乎相等的因子之积是指数函数。这是定理 1.7 较早的证明。

引理 1.29 (连续性定理)**.** 设 Y_n,Y 为 $\mathbb{R}^k$ 中的随机向量，对每个 $t\in\mathbb{R}^k$ 都有 $\varphi_{Y_n}(t)\to\varphi_Y(t)$。则 $Y_n\Rightarrow Y$。

证明. 设 f 连续且 $f,\widehat{f}$ 均属于 $L^1(\mathbb{R}^k)$；作为可积函数的逆变换，f 有界。由傅里叶反演与 Fubini 定理（因 $\widehat{f}\in L^1$ 而可用），

$$\mathbb{E}f(Y_n)=\frac{1}{(2\pi)^k}\int_{\mathbb{R}^k}\widehat{f}(\xi)\mathbb{E}[e^{i\langle\xi,Y_n\rangle}]\,d\xi=\frac{1}{(2\pi)^k}\int_{\mathbb{R}^k}\widehat{f}(\xi)\varphi_{Y_n}(-\xi)\,d\xi.$$

由于 $|\varphi_{Y_n}| \le 1$ 且 $\widehat{f} \in L^1$，控制收敛给出

$$\mathbb{E} f(Y_n) \longrightarrow \frac{1}{(2\pi)^k} \int_{\mathbb{R}^k} \widehat{f}(\xi)\varphi_Y(-\xi)\,d\xi = \mathbb{E} f(Y).$$

习题 1.3 中使用的函数均属于此类：光滑截断函数 χ_M 紧支撑，因此 $\widehat{\chi}_M$ 是 Schwartz 函数；而 $g_\delta = g * \varphi_\delta$ 可积，其 $\widehat{g}_\delta = \widehat{g}\,\widehat{\varphi}_\delta$ 为有界函数与高斯函数之积。故该论证可原样使用并得到 $Y_n \Rightarrow Y$。（第 1–2 讲引入的结果均在 $\mathbb{R}^k$ 上成立。） □

习题 1.30 (A 类)**.** 对 $\mathbb{E}|X|^k < \infty$ 的情形，在期望内求 k 次导数——给出控制变量——得到 $\varphi_X^{(k)}(0) = (-i)^k \mathbb{E}[X^k]$。通过计算 $\varphi''(0)$ 和 $\varphi^{(4)}(0)$，与 $\varphi(t) = e^{-t^2/2}$ 核对，求回 $\mathbb{E}g^2 = 1$ 和 $\mathbb{E}g^4 = 3$。

引理 1.31. 若 $\mathbb{E}X = 0$ 且 $\mathbb{E}X^2 = 1$，则 $\varphi_X(t) = 1 - t^2/2 + r(t)$，其中 $r(t)/t^2 \to 0$。

证明. 对实数 θ，$|e^{i\theta} - 1 - i\theta + \theta^2/2| \le \min(|\theta|^3/6, \theta^2)$：第一个界来自积分形式的 Taylor 余项，第二个由 $|e^{i\theta} - 1 - i\theta| \le \theta^2/2$ 得到。取 $\theta = -tX$ 并取期望，利用 $\mathbb{E}X = 0$ 和 $\mathbb{E}X^2 = 1$，

$$|r(t)| \le \mathbb{E}\min\left(\frac{|t|^3|X|^3}{6}, t^2X^2 \right).$$

除以 t^2。被积函数受可积的 X^2 控制并逐点趋于 0，故控制收敛给出 $r(t)/t^2 \to 0$。最小值的第二个分支在无需三阶矩时提供控制变量。 □

习题 1.32 (B 类)**.** 证明当复数 $z_n \to z$ 时 $(1 + z_n/n)^n \to e^z$（若 $|a|, |b| \le M$，则 $|a^n - b^n| \le nM^{n-1}|a - b|$；取 $b = e^{z_n/n}$）。结合引理 1.31 得到 $\varphi_{S_n}(t) = [\varphi_{X_1}(t/\sqrt{n})]^n \to e^{-t^2/2}$，并推得 $S_n \Rightarrow \mathcal{N}(0,1)$。指出何处使用独立性，何处使用同分布。

习题 1.33 (A 类)**.** 设 $B \sim \mathrm{Bernoulli}(p)$，证明 $\varphi_B(t) = 1 + p(e^{-it} - 1)$。对独立的 $B_{n,i} \sim \mathrm{Bernoulli}(\lambda/n)$，令 $N_n = \sum_i B_{n,i}$，证明 $\varphi_{N_n}(t) \to \exp[\lambda(e^{-it} - 1)]$，并通过级数求和将极限辨认为 $\mathrm{Poisson}(\lambda)$。与习题 1.32 是相同的三行计算，只有归一化不同。

习题 1.34 (B 类)**.** 对中心化阵列 $X_{n,i} = B_{n,i} - \lambda/n$，证明 $s_n^2 = \lambda(1 - \lambda/n)$，且对每个 $\varepsilon < 1/\sqrt{\lambda}$ 都有 $L_n(\varepsilon) \to 1$，所以定义 1.8 不成立。取 $\lambda = 3$、$n = 10, 100, 10^4$ 精确计算 $L_n(1/2)$；应得到 0、0.970、1.000，且第一个应恰好为 0——说明原因。

习题 1.35 (C 类)**.** 取 $X_{n,i} = \pm 1$（$i \le n$）及另一个求和项 $X_{n,n+1} = \pm\sqrt{n}$，全部独立且对称。证明 $s_n^2 = 2n$，对 $\varepsilon < 1/\sqrt{2}$ 有 $L_n(\varepsilon) \ge 1/2$，且 $s_n^{-1}\sum_i X_{n,i}$ 的极限特征函数为 $e^{-t^2/4}\cos(t/\sqrt{2})$。给出使其为零的 t，并由此得出 $s_n^{-1}\sum_i X_{n,i}$ 不依分布收敛到任何高斯分布。Feller 条件在此也不成立，故注 1.10(c) 不适用，必须计算变换。无需事先知道极限存在，为什么一个零点就足够?

习题 1.36 (C 类)**.** 证明对 $X_i = \pm 1$，当 $\alpha > 1/2$ 时，不可能有 $\sup_z |\mathbb{P}(S_n \le z) - \Phi(z)| \le Cn^{-\alpha}$ 这样的界。当 n 为偶数时，$\mathbb{P}(S_n = 0) = \binom{n}{n/2} 2^{-n}$，由 Stirling 公式其渐近值为 $\sqrt{2/(\pi n)}$；现比较 $z = 0$ 附近的 $\mathbb{P}(S_n \le z)$ 与 $\Phi(z)$。用一句话解释为什么格点型求和项是第 1.6 节表中最慢的一行。

习题 1.37 (C 类)**.** 证明对任意实随机变量 Y 和任意 $u>0$，

$$\mathbb{P}(|Y|\geq 2/u)\leq \frac{1}{u}\int_{-u}^{u}(1-\varphi_Y(t))\,dt.$$

推得若 $\varphi_{Y_n}\to\psi$ 逐点成立且 ψ 在 0 处连续，则当 $K\to\infty$ 时 $\sup_n \mathbb{P}(|Y_n|>K)\to 0$。这是连续性定理中无需预先知道极限分布的一半。另一半——ψ 因而是某个随机变量的变换——是我们不需要的紧致性论证，因为引理 1.29 每次应用时极限已知。

> **第 3 讲指定作业，第 4 讲开始时交：** 习题 1.3、1.13、1.14、1.21、1.22、1.25、1.32、1.35——两道 A 类、三道 B 类、三道 C 类。第 1 节其余习题均属题库：供选做、属于考试范围，但无需上交。时间不足时请做 C 类题。

2 Stein 方法

定理 1.7 将高斯分布描述为极限。它还可以用一个恒等式来刻画。

> **问题：** 是否存在一个标准高斯分布满足而其他分布均不满足的恒等式？若存在，那么证明一个分布近似高斯，就转化为证明它近似满足该恒等式。

2.1 刻画

定理 2.1 (Stein 引理)**.** 随机变量 W 服从标准高斯分布，当且仅当对每个有界且导数有界的 $f\in C^1(\mathbb{R})$，

$$\mathbb{E}[Wf(W)]=\mathbb{E}[f'(W)].$$

正向证明. 令 $\varphi(x)=(2\pi)^{-1/2}e^{-x^2/2}$，则 $\varphi'(x)=-x\varphi(x)$。因此

$$\mathbb{E}[f'(g)]=\int f'\varphi=-\int f\varphi'=\int xf(x)\varphi(x)\,dx=\mathbb{E}[gf(g)].$$

□

反向在第 2.2 节证明。

注 2.2 (指数检验函数)**.** 取 $f(x)=e^{-itx}$，Stein 恒等式变成

$$\mathbb{E}[We^{-itW}]=-it\mathbb{E}[e^{-itW}],$$

即 $\varphi'(t)=-t\varphi(t)$，这是第 1–2 讲引理 1.10 的微分方程。分离一个求和项并作 Taylor 展开以得到 $\varphi'_{S_n}\approx -t\varphi_{S_n}$，即可证明中心极限定理；这条路径见第 1.9* 节。

习题 2.3 (B 类)**.** 向量形式。设 $X\sim\mathcal{N}(0,\Sigma)$ 取值于 $\mathbb{R}^d$，其中 $\Sigma\succeq 0$ 可以奇异；设 $f:\mathbb{R}^d\to\mathbb{R}$ 满足 $\widehat{f}$ 和 $|\xi|\widehat{f}(\xi)$ 可积，傅里叶变换及反演公式遵循第 1–2 讲命题 1.1。

(a) 证明

$$\mathbb{E}[X_j f(X)] = \sum_k \Sigma_{jk}\mathbb{E}[\partial_k f(X)], \qquad \text{即} \quad \mathbb{E}[Xf(X)] = \Sigma\mathbb{E}[\nabla f(X)].$$

关于变换的两个事实：乘以 X_j 作用在 $\xi \mapsto \mathbb{E}[e^{i\langle X,\xi\rangle}]$ 上相当于 $-i\partial_{\xi_j}$，而由第 1–2 讲定义 1.3，该函数为 $e^{-\xi^\top\Sigma\xi/2}$，故

$$\mathbb{E}[X_j e^{i\langle X,\xi\rangle}] = i(\Sigma\xi)_j e^{-\xi^\top\Sigma\xi/2};$$

并且 $\widehat{\partial_k f}(\xi) = i\xi_k\widehat{f}(\xi)$。用傅里叶反演写出所求恒等式两侧并比较被积函数。$\widehat{f} \in L^1(\mathbb{R}^d)$ 且 $\mathbb{E}|X_j| < \infty$ 保证 Fubini 定理可用；$\xi_k\widehat{f} \in L^1$ 则保证可通过反演恢复 $\partial_k f$。任何地方都没有用到 Σ 的非退化性。

(b) 反过来证明，若对每个有界且导数有界的 $F \in C^1(\mathbb{R}^d;\mathbb{R}^d)$，有

$$\mathbb{E}[\langle W, F(W)\rangle] = \mathbb{E}[\operatorname{tr}(\Sigma DF(W))],$$

则 $W \sim \mathcal{N}(0,\Sigma)$。取 $F(x) = vf(\langle v,x\rangle)$，化为对 $\langle v,W\rangle$ 应用定理 2.1，再用第 1–2 讲推论 1.7 完成证明。单独处理 $v^\top\Sigma v = 0$ 的情形。

(c) 矩阵形式。设随机矩阵 M 的元素联合高斯且均值为 0，F 在 $\mathbb{R}^{n\times m}$ 上满足上面的假设。证明

$$\mathbb{E}[M_{ij}F(M)] = \sum_{k,l}\mathbb{E}[M_{ij}M_{kl}]\,\mathbb{E}\left[\frac{\partial F}{\partial M_{kl}}(M)\right].$$

由 (a) 一行可得：矩阵是索引为一对指标的向量，其协方差 $\Sigma_{(ij),(kl)} = \mathbb{E}[M_{ij}M_{kl}]$，而 (a) 的证明完全没有使用索引集的形状。

2.2 Stein 方程

定理 2.1 表明，$W \sim \mathcal{N}(0,1)$ 恰当且仅当对每个容许的 f，

$$\mathbb{E}[f'(W) - Wf(W)] = 0.$$

我们需要它的定量形式：对给定的检验函数 h，给出 $\mathbb{E}h(W) - \mathbb{E}h(g)$ 的界。

假设对这个 h 能构造函数 f，使对每个 $w \in \mathbb{R}$ 都有 $f'(w) - wf(w) = h(w) - \mathbb{E}h(g)$。两边都是实变量函数，而 g 仅通过常数 $\mathbb{E}h(g)$ 进入；因此可将 $w = W$ 代入该恒等式并取平均，得到

$$\mathbb{E}h(W) - \mathbb{E}h(g) = \mathbb{E}[f'(W) - Wf(W)].$$

因此整个问题就是从 h 构造 f。固定 h，寻找满足下式的 f：

$$f'(w) - wf(w) = h(w) - \mathbb{E}h(g). \tag{3}$$

在第 2.2、2.3 节中，始终取 $h \in C^3(\mathbb{R})$，且 h', h'', h''' 有界；这是引理 1.2 中的函数类。对 $s \geq 0$，令

$$(T_s h)(w) = \mathbb{E}\left[h\left(e^{-s}w + \sqrt{1-e^{-2s}}\,g\right)\right].$$

独立高斯变量的方差相加，且 $e^{-2t}(1-e^{-2s})+1-e^{-2t}=1-e^{-2(s+t)}$，故 $T_sT_t=T_{s+t}$：这是 Ornstein–Uhlenbeck 半群。它在 $T_0h=h$ 与 $T_sh\to\mathbb{E}h(g)$ 之间插值，生成元为

$$Lu=\lim_{s\downarrow 0}\frac{T_su-u}{s}=u''-wu',$$

见下方证明中的计算；且 $\partial_sT_s=LT_s$。

现在由两个观察构造 f_h。记 $\widetilde{h}=h-\mathbb{E}h(g)$，则 $T_s\widetilde{h}=T_sh-\mathbb{E}h(g)\to 0$。第一，对 s 作望远镜积分，

$$\widetilde{h}=T_0\widetilde{h}-\lim_{s\to\infty}T_s\widetilde{h}=-\int_0^\infty\partial_sT_s\widetilde{h}\,ds=-L\int_0^\infty T_s\widetilde{h}\,ds.$$

第二，Stein 算子 $Af=f'-wf$ 是从 L 中提出一个导数而得：$A(u')=(u')'-wu'=Lu$。因此，取 $u=-\int_0^\infty T_s\widetilde{h}\,ds$ 并令 $f=u'$，就解得 $Af=\widetilde{h}$；即

$$f_h=-\int_0^\infty\partial_wT_sh\,ds,$$

常数 $\mathbb{E}h(g)$ 在 ∂_w 下消失。T_s 每对 w 求一次导数都会产生一个因子 e^{-s}，这使该积分收敛，并给出下面的界。

引理 2.4 (解及其导数)**.** 方程 (3) 恰有一个有界解，即

$$f_h=-\int_0^\infty\partial_wT_sh\,ds,\qquad f_h(w)=-\int_0^\infty e^{-s}\mathbb{E}\left[h'\left(e^{-s}w+\sqrt{1-e^{-2s}}\,g\right)\right]ds,$$

且它满足

$$\|f_h\|_\infty\le\|h'\|_\infty,\qquad\|f_h'\|_\infty\le\tfrac{1}{2}\|h''\|_\infty,\qquad\|f_h''\|_\infty\le\tfrac{1}{3}\|h'''\|_\infty.$$

特别地，$f_h\in C^2(\mathbb{R})$。

证明. 令 $b_s=\sqrt{1-e^{-2s}}$、$u(s,w)=(T_sh)(w)=\mathbb{E}[h(e^{-s}w+b_sg)]$，则 $u(0,w)=h(w)$，且当 $s\to\infty$ 时 $u(s,w)\to\mathbb{E}h(g)$。对 s 求导并使用 $\dot{b}_s=e^{-2s}/b_s$，

$$\begin{aligned}\partial_su&=\mathbb{E}\left[h'(e^{-s}w+b_sg)\left(-e^{-s}w+\frac{e^{-2s}}{b_s}g\right)\right]\\&=-e^{-s}w\mathbb{E}[h']+\frac{e^{-2s}}{b_s}\mathbb{E}[gh'].\end{aligned}$$

对 $g\mapsto h'(a+b_sg)$ 应用定理 2.1 得到 $\mathbb{E}[gh'(a+b_sg)]=b_s\mathbb{E}[h''(a+b_sg)]$，这也消除了 $s=0$ 处表面上的奇异性。由于 $\partial_wu=e^{-s}\mathbb{E}[h']$ 且 $\partial_w^2u=e^{-2s}\mathbb{E}[h'']$，上式恰好表示

$$\partial_su=\partial_w^2u-w\partial_wu.$$

现在 $f_h(w)=-\int_0^\infty\partial_wu(s,w)\,ds$ 即为所显示的公式，且

$$\begin{aligned}f_h'(w)-wf_h(w)&=-\int_0^\infty(\partial_w^2u-w\partial_wu)\,ds=-\int_0^\infty\partial_su\,ds\\&=u(0,w)-\lim_{s\to\infty}u(s,w)=h(w)-\mathbb{E}h(g),\end{aligned}$$

故 f_h 解式 (3)。两个解之差满足 $f' = wf$，因此形如 $ce^{w^2/2}$，仅当 $c = 0$ 时有界；而 f_h 有界，其上界为 $\|h'\|_\infty \int_0^\infty e^{-s} ds$。在积分内求导是合法的，因为第 k 个被积函数被 $e^{-ks}\|h^{(k)}\|_\infty$ 控制，由此得

$$f_h'(w) = -\int_0^\infty e^{-2s}\mathbb{E}[h''(e^{-s}w + b_s g)]\, ds,$$
$$f_h''(w) = -\int_0^\infty e^{-3s}\mathbb{E}[h'''(e^{-s}w + b_s g)]\, ds,$$

而 $\int_0^\infty e^{-ks} ds = 1/k$。 □

注 2.5. 将式 (3) 作为一阶线性方程求解，也可得到经典闭式

$$f_h(w) = e^{w^2/2} \int_{-\infty}^{w} [h(x) - \mathbb{E}h(g)] e^{-x^2/2}\, dx.$$

由唯一性，它是同一个函数。

取 $f = f_h$，上面的恒等式成为

$$\mathbb{E}h(W) - \mathbb{E}h(g) = \mathbb{E}[f_h'(W) - W f_h(W)]. \tag{4}$$

这就证明了定理 2.1 的反向。那里将检验函数限制为 C^1 不会损失一般性：式 (3) 的任何解都满足 $f' = wf + h - \mathbb{E}h(g)$，右侧连续，故每个解自动属于 C^1。由引理 2.4，f_h 就是这样的函数，它有界且导数有界，因而容许。所以若 W 满足该恒等式，式 (4) 右侧为零；于是对我们函数类中的每个 h，$\mathbb{E}h(W) = \mathbb{E}h(g)$，再由引理 1.2 和习题 1.3 得 $W \overset{d}{=} g$。

2.3 带速率的中心极限定理

定理 2.6. 设 $X_1, \dots, X_n$ 独立同分布，均值为 0、方差为 1，且 $\mathbb{E}|X_1|^3 < \infty$。则对每个导数有界的 $h \in C^3(\mathbb{R})$，

$$|\mathbb{E}h(S_n) - \mathbb{E}h(g)| \le \frac{\|h'''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}}.$$

证明. 记 $W = S_n$，令 $W^{(i)} = W - X_i/\sqrt{n}$，它与 X_i 独立，并简记 $f = f_h$。于是

$$\mathbb{E}[W f(W)] = \frac{1}{\sqrt{n}} \sum_i \mathbb{E}[X_i f(W)].$$

将 $f(W) = f(W^{(i)}) + \frac{X_i}{\sqrt{n}} f'(W^{(i)}) + R_i$ 作 Taylor 展开，余项满足 $|R_i| \le \frac{\|f''\|_\infty}{2} \frac{X_i^2}{n}$。对每个 i，

$$\mathbb{E}[X_i f(W)] = \underbrace{\mathbb{E}[X_i]}_{=0} \mathbb{E}[f(W^{(i)})] + \frac{1}{\sqrt{n}} \underbrace{\mathbb{E}[X_i^2]}_{=1} \mathbb{E}[f'(W^{(i)})] + \mathbb{E}[X_i R_i],$$

其中 $|\mathbb{E}[X_i R_i]| \le \|f''\|_\infty \mathbb{E}|X_1|^3/(2n)$，而前两项的期望可分解是因为 X_i 与 $W^{(i)}$ 独立。求和得

$$\left| \mathbb{E}[W f(W)] - \frac{1}{n} \sum_i \mathbb{E}[f'(W^{(i)})] \right| \le \frac{\|f''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}}.$$

每个 $\mathbb{E}[f'(W^{(i)})]$ 与 $\mathbb{E}[f'(W)]$ 之差的绝对值至多为 $\|f''\|_\infty \mathbb{E}|X_i|/\sqrt{n}$，因此

$$\begin{aligned}|\mathbb{E}[f'(W) - Wf(W)]| &\le \frac{\|f''\|_\infty}{\sqrt{n}} \left(\mathbb{E}|X_1| + \tfrac{1}{2}\mathbb{E}|X_1|^3\right) \\ &\le \frac{3\|f''\|_\infty \mathbb{E}|X_1|^3}{2\sqrt{n}},\end{aligned}$$

因为 $\mathbb{E}|X_1| \le (\mathbb{E}X_1^2)^{1/2} = 1 \le (\mathbb{E}X_1^2)^{3/2} \le \mathbb{E}|X_1|^3$。现在将引理 2.4 的 $\|f''\|_\infty \le \frac{1}{3}\|h'''\|_\infty$ 代入式 (4)。 □

注 2.7. 对同一函数类，定理 1.7 给出 $\frac{\|h'''\|_\infty}{6\sqrt{n}}(\mathbb{E}|X_1|^3 + 2\sqrt{2/\pi})$，所以两个界只差一个常数因子。

同样的论证配合不同的刻画恒等式，可给出全变差距离下带速率的 Poisson 极限定理（第 2.4 节），并且不需要独立性（第 2.5* 节）。

2.4 对 Poisson 分布使用同一论证

译注： 以下含 $1/\lambda$、π_k 分母的递推和界取 $\lambda > 0$。$\lambda = 0$ 是集中于 0 的退化分布；Le Cam 情形此时所有 $p_i = 0$，两分布相同、全变差为 0，无须使用这些除法。

上面的论证没有任何部分专属于高斯分布；用到的只是刻画恒等式。记 Poisson(λ) 的权重为 $\pi_k = e^{-\lambda}\lambda^k/k!$，$\pi(A) = \sum_{k\in A}\pi_k$；回忆在 $\{0,1,2,\ldots\}$ 上的分布之间，

$$d_{\mathrm{TV}}(X,Y) = \sup_{A\subseteq\{0,1,2,\ldots\}} |\mathbb{P}(X\in A) - \mathbb{P}(Y\in A)|.$$

定理 2.8 (Chen 引理)**.** 取值于 $\{0,1,2,\ldots\}$ 的随机变量 N 服从 Poisson(λ)，当且仅当对每个有界函数 $f:\{0,1,2,\ldots\}\to\mathbb{R}$，

$$\mathbb{E}[\lambda f(N+1) - Nf(N)] = 0.$$

正向证明.

$$\mathbb{E}[Nf(N)] = \sum_{k\ge1} ke^{-\lambda}\frac{\lambda^k}{k!}f(k) = \lambda\sum_{j\ge0} e^{-\lambda}\frac{\lambda^j}{j!}f(j+1) = \lambda\mathbb{E}[f(N+1)].$$

□

反向和定量陈述来自式 (3) 的类似物。固定 A，寻找满足下式的 f：

$$\lambda f(k+1) - kf(k) = \mathbf{1}_A(k) - \pi(A), \qquad k \ge 0. \tag{5}$$

此处差分算子代替导数，也没有需要积分的半群：式 (5) 是一阶递推，可以直接求解。

引理 2.9. 令 $f_A(0) = 0$。则式 (5) 有唯一解

$$f_A(k) = \frac{1}{k\pi_k}\sum_{j<k}\pi_j(\mathbf{1}_A(j) - \pi(A)) = -\frac{1}{k\pi_k}\sum_{j\ge k}\pi_j(\mathbf{1}_A(j) - \pi(A)), \qquad k \ge 1,$$

它有界，且

$$|(k-\lambda)f_A(k)| \le 1 \quad \text{对每个} k, \qquad \|\Delta f_A\|_\infty := \sup_k |f_A(k+1) - f_A(k)| \le \frac{2}{\lambda}.$$

证明. 记 $g = \mathbf{1}_A - \pi(A)$，则 $\sum_j \pi_j g(j) = 0$。将式 (5) 乘以 π_k 并利用 $\lambda\pi_k = (k+1)\pi_{k+1}$，得到

$$(k+1)\pi_{k+1} f(k+1) - k\pi_k f(k) = \pi_k g(k),$$

这是关于 $k \mapsto k\pi_k f(k)$ 的望远镜递推，在 $k = 0$ 时从 0 开始。求和给出第一个公式，第二个由 $\sum_j \pi_j g(j) = 0$ 得到。由于 $|g| \le 1$，对于 $N \sim \mathrm{Poisson}(\lambda)$，

$$|f_A(k)| \le \frac{1}{k\pi_k} \min\bigl(\mathbb{P}(N \le k-1), \mathbb{P}(N \ge k)\bigr). \tag{6}$$

当 $k > \lambda$ 时，比值 $\pi_{k+m}/\pi_k = \prod_{r=1}^{m} \lambda/(k+r)$ 至多为 $(\lambda/k)^m$，故 $\mathbb{P}(N \ge k) \le \pi_k k/(k-\lambda)$，由式 (6) 得 $|f_A(k)| \le 1/(k-\lambda)$。当 $1 \le k \le \lambda$ 时，比值 π_{k-1-m}/π_{k-1} 至多为 $((k-1)/\lambda)^m$，故 $\mathbb{P}(N \le k-1) \le \pi_{k-1}\lambda/(\lambda - k + 1)$；由 $\pi_{k-1} = k\pi_k/\lambda$ 和式 (6) 得 $|f_A(k)| \le 1/(\lambda - k + 1)$。两种情况下均有 $|(k-\lambda) f_A(k)| \le 1$，$k = 0$ 的情形显然。第一个界还说明 $f_A(k) \to 0$，所以 f_A 有界。

最后，将式 (5) 两边减去 $\lambda f(k)$，得到

$$\Delta f_A(k) = \frac{(k-\lambda) f_A(k) + g(k)}{\lambda},$$

分子的两项绝对值均至多为 1。 □

将 $k = W$ 代入式 (5) 并取期望，得到式 (4) 的类似物：

$$\mathbb{P}(W \in A) - \pi(A) = \mathbb{E}[\lambda f_A(W+1) - W f_A(W)]. \tag{7}$$

这证明了定理 2.8 的反向：若 W 满足恒等式，由于每个 f_A 有界，右侧对每个 A 都为零，故 $W \sim \mathrm{Poisson}(\lambda)$。

定理 2.10 (Le Cam)**.** 设 $B_1, \dots, B_n$ 独立，$B_i \sim \mathrm{Bernoulli}(p_i)$，令 $\lambda = \sum_i p_i$。则

$$d_{\mathrm{TV}}\left(\sum_i B_i, \mathrm{Poisson}(\lambda) \right) \le \frac{2}{\lambda} \sum_i p_i^2 \le 2 \max_i p_i.$$

证明. 令 $W = \sum_i B_i$、$W_i = W - B_i$，后者与 B_i 独立。固定 A 并记 $f = f_A$。因为 $B_i f(W) = B_i f(W_i + 1)$，

$$\mathbb{E}[W f(W)] = \sum_i \mathbb{E}[B_i f(W_i + 1)] = \sum_i p_i \mathbb{E}[f(W_i + 1)],$$

而 $\lambda = \sum_i p_i$ 给出 $\mathbb{E}[\lambda f(W+1)] = \sum_i p_i \mathbb{E}[f(W_i + B_i + 1)]$。相减得

$$\mathbb{E}[\lambda f(W+1) - W f(W)] = \sum_i p_i \mathbb{E}[f(W_i + B_i + 1) - f(W_i + 1)].$$

当 $B_i = 0$ 时方括号为零，当 $B_i = 1$ 时等于 $\Delta f(W_i + 1)$；由于 B_i 与 W_i 独立，第 i 项为 $p_i^2 \mathbb{E}[\Delta f(W_i + 1)]$。故由式 (7) 和引理 2.9，

$$|\mathbb{P}(W \in A) - \pi(A)| \le \|\Delta f_A\|_\infty \sum_i p_i^2 \le \frac{2}{\lambda} \sum_i p_i^2,$$

该界对 A 一致成立。定理中的第二个不等式来自 $\sum_i p_i^2 \le (\max_i p_i) \sum_i p_i$。 □

推论 2.11 (Poisson 极限定理)**.** 设 $B_{n,i} \sim \mathrm{Bernoulli}(p_{n,i})$ $(i \le k_n)$ 独立，且 $\max_i p_{n,i} \to 0$、$\sum_i p_{n,i} \to \lambda > 0$。则 $\sum_i B_{n,i} \Rightarrow \mathrm{Poisson}(\lambda)$。

证明. 界 $2\max_i p_{n,i}$ 趋于 0，且当 $\lambda_n \to \lambda$ 时 $\mathrm{Poisson}(\lambda_n) \Rightarrow \mathrm{Poisson}(\lambda)$。 □

这是第 1.6 节边界的 Poisson 一侧，且与定理 2.6 不同，它是全变差距离下的界。取 $p_i = \lambda/n$，该界为 $2\lambda/n$；当 $\lambda = 3$、$n = 100$ 时为 0.06，而真实全变差距离为 0.0076。引理 2.9 中常数 2 可改进为 $1 - e^{-\lambda}$，且可取到。

同一技巧覆盖第 1.6 节边界的两侧；改变的只是刻画恒等式。

2.5 * 独立性用在何处

本节不在课堂讲授。定理 2.6 的证明恰在一处使用独立性，以计算

$$\mathbb{E}[X_i f(W^{(i)})] = \mathbb{E}[X_i]\mathbb{E}[f(W^{(i)})].$$

任何其他计算该期望的途径都可以，最廉价的是耦合。

定义 2.12 (可交换对)**.** 若 $(W, W') \overset{d}{=} (W', W)$，则称 (W, W') 可交换。若还对某个 $a > 0$ 满足 $\mathbb{E}[W' - W \mid W] = -aW$，则称其为 Stein 对。

习题 2.13 (A 类)**.** 设 (W, W') 可交换，F 反对称，即 $F(x, y) = -F(y, x)$，且 $\mathbb{E}|F(W, W')| < \infty$。证明 $\mathbb{E}F(W, W') = 0$。一行即可；其余工作全在于选择 F。

习题 2.14 (B 类)**.** 对 $F(x, y) = (y - x)(f(x) + f(y))$ 应用上述结论，将 $f(W')$ 在 W 处展开到一阶，并利用定义 2.12 得到

$$\mathbb{E}[f'(W) - Wf(W)] = \mathbb{E}\left[f'(W)\left(1 - \frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid W]\right)\right] + \mathrm{err},$$
$$|\mathrm{err}| \le \frac{\|f''\|_\infty}{4a}\mathbb{E}|W' - W|^3.$$

高斯近似现要求两件事：$\frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid W]$ 接近 1，以及 $W' - W$ 小。

习题 2.15 (B 类)**.** 标准构造的对。取 $W = S_n$，令 I 在 $\{1, \dots, n\}$ 上均匀，X_I' 是独立的 X_I 副本；令 $W' = W - (X_I - X_I')/\sqrt{n}$。证明 (W, W') 可交换且 $\mathbb{E}[W' - W \mid X_1, \dots, X_n] = -W/n$，故 $a = 1/n$；然后证明

$$\mathbb{E}[(W' - W)^2 \mid X_1, \dots, X_n] = n^{-2}\sum_i (X_i^2 + 1),$$
$$\frac{1}{2a}\mathbb{E}[(W' - W)^2 \mid X_1, \dots, X_n] = \tfrac{1}{2}\left(1 + \frac{1}{n}\sum_i X_i^2\right),$$

后者与 1 的 L^2 距离为 $\frac{1}{2}\sqrt{\mathrm{Var}(X_1^2)/n}$。再假设 $\mathbb{E}X_1^4 < \infty$，推得与定理 2.6 同量级的界。独立性进入两次——通过重新采样的副本，以及通过 $\frac{1}{n}\sum_i X_i^2$ 的方差——但两处都不是第 2.3 节中的乘积公式。

下面是一个任何形式的独立性都不适用的和。设 π 是 $\{1, \dots, n\}$ 上的均匀随机置换，令 $I_i = \mathbf{1}\{\pi(i) = i\}$，$W = \sum_i I_i$ 计数不动点。

习题 2.16 (A 类)**.** 证明当 $n \geq 2$ 时 $\mathbb{E}W = \operatorname{Var} W = 1$，并证明 $\mathbb{P}(I_1 = I_2 = 1) \neq \mathbb{P}(I_1 = 1)\mathbb{P}(I_2 = 1)$。一名学生取 $p_i = 1/n$、$\lambda = 1$，应用定理 2.10 得出 $d_{\mathrm{TV}}(W, \mathrm{Poisson}(1)) \leq 2/n$。指出哪个假设不成立，并说明为何结论碰巧正确也不能挽救该论证。

引入的结果：耦合形式的 Chen–Stein

令 $W = \sum_{i \leq n} I_i$，其中 $I_i \sim \mathrm{Bernoulli}(p_i)$，不一定相互独立，$\lambda = \sum_i p_i$。若对每个 i 都能在与 W 相同的概率空间上构造变量 V_i，使其分布等于给定 $I_i = 1$ 时 $W - 1$ 的分布，则

$$d_{\mathrm{TV}}(W, \mathrm{Poisson}(\lambda)) \leq \min(1, \lambda^{-1}) \sum_i p_i \mathbb{E}|W - V_i|.$$

习题 2.17 (C 类)**.** 构造耦合。固定 i；若 $\pi(i) = i$ 则令 $\sigma = \pi$，否则令 $\sigma = \pi \circ (i\ \pi^{-1}(i))$。证明始终有 $\sigma(i) = i$，σ 在固定 i 的置换中均匀，并且当 $\pi(i) \neq i$ 时 $W(\sigma) - W(\pi) \in \{1, 2\}$——当且仅当 π 在 i 处有一个二循环时取值 2。推得 $\mathbb{E}|W - V_i| \leq 2/n$，因而 $d_{\mathrm{TV}}(W, \mathrm{Poisson}(1)) \leq 2/n$。

容斥原理给出 $\mathbb{P}(W = 0) = \sum_{k \leq n} (-1)^k / k!$；当 $n = 4, 6, 10$ 时，其与 e^{-1} 的距离分别为 7.1×10^{-3}、1.8×10^{-4} 和 2.3×10^{-8}。当 $n = 10$ 时，此方法的误差相差多少个数量级？它具有什么容斥原理所没有的优点？

第 1.8* 节推导宽网络极限并计算反余弦核；第 1.9* 节给出中心极限定理的特征函数证明、Poisson 情形的同类计算，以及边界两侧的 Lindeberg 条件；第 2.5* 节推导可交换对的界及完全没有独立性的情形。

第 4 讲指定作业，第 5 讲开始时交：习题 2.13–2.17——两道 A 类、两道 B 类、一道 C 类。习题 2.3 属于题库。时间不足时请做 C 类题。



现代机器学习中的概率

ORF 526 课程材料译稿

第 3–4 讲习题解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

解答

编号与讲义一致。C 类习题的关键思路置于框中；掌握思路后其余部分是常规推导，这也正是分类的含义。

第 3–4 讲：收敛到高斯分布的含义（第 1.2 节）

1.3（C）

> 假设已经限制了 X_n 在远处所放置的概率质量：用光滑截断函数测试即可。紧性由此自动得到，之后只需作光滑化。

取光滑函数 χ，满足 $0 \le \chi \le 1$、在 $\{|x| \le 1\}$ 上为 1，在 $\{|x| \ge 2\}$ 上为 0；令 $\chi_M(x) = \chi(x/M)$，每个 M 下它都属于测试函数类。由于 $\mathbf{1}_{\{|X|>M\}} \to 0$ 逐点成立且以 1 为上界，控制收敛定理给出 $\mathbb{P}(|X| > M) \to 0$；取 M 使 $\mathbb{P}(|X| > M) < \epsilon$。于是 $\mathbb{E}\chi_M(X) \ge \mathbb{P}(|X| \le M) > 1-\epsilon$，故

$$\limsup_n \mathbb{E}[1 - \chi_M(X_n)] = 1 - \mathbb{E}\chi_M(X) < \epsilon.$$

现令 f 为有界连续函数，设 $g = f\chi_M$，它连续且支撑于 $\{|x| \le 2M\}$，因此一致连续。对 $G \sim \mathcal{N}(0, I_k)$ 令

$$g_\delta(x) = \mathbb{E}[g(x + \delta G)] = \int g(y)\phi_\delta(x-y)dy.$$

在积分号下求导（ϕ_δ 的差商由关于 y 的可积函数控制），每阶导数

$$\partial^\alpha g_\delta(x) = \int g(y)\partial^\alpha \phi_\delta(x-y)dy$$

都以 $\|g\|_\infty \|\partial^\alpha \phi_\delta\|_{L^1}$ 为界，故 g_δ 属于测试类。若 ω 是 g 的连续模，则关于 x 一致地有

$$|g_\delta(x) - g(x)| \le \mathbb{E}|g(x+\delta G) - g(x)| \le \mathbb{E}\min\{\omega(\delta|G|), 2\|g\|_\infty\} \xrightarrow[\delta\to 0]{} 0.$$

最后，

$$\begin{aligned}|\mathbb{E}f(X_n) - \mathbb{E}f(X)| \le{}& \|f\|_\infty \mathbb{E}[1-\chi_M(X_n)] + \|f\|_\infty \mathbb{E}[1-\chi_M(X)] \\ &+ 2\|g - g_\delta\|_\infty + |\mathbb{E}g_\delta(X_n) - \mathbb{E}g_\delta(X)|.\end{aligned}$$

取 $\limsup_n$：最后一项由假设趋零，前两项之和至多为 $2\|f\|_\infty \epsilon$。再令 $\delta \to 0$，随后令 $\epsilon \to 0$。

Lindeberg 与 Feller（第 1.6 节）

1.13（A） 此处 $s_n^2 = n\sigma^2$，每行各项均与 X_1 同分布，因此

$$L_n(\epsilon) = \frac{1}{n\sigma^2}\sum_{i=1}^n \mathbb{E}[X_i^2 \mathbf{1}_{\{|X_i| > \epsilon\sigma\sqrt{n}\}}] = \frac{1}{\sigma^2}\mathbb{E}[X_1^2 \mathbf{1}_{\{|X_1| > \epsilon\sigma\sqrt{n}\}}].$$

被积函数逐点趋零，且由可积的 X_1^2 控制；控制收敛定理给出 $L_n(\epsilon) \to 0$。因此只需二阶矩便可应用定理 1.9，而定理 1.7 假设三阶矩。三阶矩并非无用：它换来了 $n^{-1/2}$ 的速率，定理 1.9 不提供该速率。

1.14（C）

> Feller 条件看不到罕见的大值；Lindeberg 条件只看到它们。该数组是高斯与 Poisson 的叠加，极限记录了两者。[a]
>
> [a]原文的“叠加”在此应结合后面的极限式理解：有限 n 的数组取离散值，并非本身就是高斯与 Poisson 变量之和。

$\mathrm{Var}(X_{n,i}) = 1\cdot(1-1/n) + n\cdot(1/n) = 2-1/n$，故 $s_n^2 = 2n-1$ 且

$$\max_i \frac{\mathrm{Var}(X_{n,i})}{s_n^2} = \frac{2-1/n}{2n-1} \longrightarrow 0,$$

即 Feller 条件成立。当 $\epsilon \le 1/\sqrt{2}$，有 $\epsilon^2 \le 1/2 < n/(2n-1)$，即 $\epsilon s_n < \sqrt{n}$；而充分大的 n 下 $\epsilon s_n > 1$。因此 $\{|X_{n,i}| > \epsilon s_n\} = \{|X_{n,i}| = \sqrt{n}\}$，且

$$L_n(\epsilon) = \frac{1}{2n-1}\cdot n\cdot\left(n\cdot\frac{1}{n}\right) = \frac{n}{2n-1} \longrightarrow \frac{1}{2}.$$

Lindeberg 条件不成立。Feller 条件成立，故可用注 1.10(c) 的逆否命题：该数组不满足中心极限定理。这是注 1.10(b) 所承诺的数组。

直接计算：$\varphi_{n,i}(t) = (1-1/n)\cos t + (1/n)\cos(t\sqrt{n})$，故在 $s_n = \sqrt{2n-1}$ 下，

$$\begin{aligned}\varphi_{T_n}(t) &= \left[(1-\tfrac{1}{n})\cos\frac{t}{s_n} + \tfrac{1}{n}\cos\frac{t\sqrt{n}}{s_n}\right]^n \\ &= \left[1 - \frac{1}{n}\left(\frac{t^2}{4} + 1 - \cos\frac{t}{\sqrt{2}}\right) + o\!\left(\frac{1}{n}\right)\right]^n,\end{aligned}$$

这里使用了 $\cos(t/s_n) = 1 - t^2/[2(2n-1)] + O(n^{-2})$ 和 $t\sqrt{n}/s_n \to t/\sqrt{2}$。于是

$$\varphi_{T_n}(t) \longrightarrow \exp(-t^2/4)\cdot\exp(\cos(t/\sqrt{2}) - 1),$$

这是 $\mathcal{N}(0,1/2)$ 与速率为 1、跳跃为 $\pm 1/\sqrt{2}$ 的复合 Poisson 分布的卷积。一半方差来自 ± 1 并变成高斯；另一半来自罕见的 $\pm\sqrt{n}$，并未变成高斯。当 $t = \sqrt{2}\pi$，该极限为 $e^{-\pi^2/2-2}$，而标准高斯的值为 $e^{-\pi^2/2}$。

译注：最后一个值按原文保留，但在 $t = \sqrt{2}\pi$ 处，标准高斯特征函数为 $e^{-t^2/2} = e^{-\pi^2}$。前面的复合 Poisson 与高斯卷积极限 $e^{-\pi^2/2-2}$ 则计算无误。

纪录（第 1.7 节）

1.21（A） 数组 $X_{n,i} = B_{n,i} - p_{n,i}$ 独立且中心化，满足 $|X_{n,i}| \le 1$ 和 $s_n = \sigma_n \to \infty$，故引理 1.15 给出 Lindeberg 条件，定理 1.9 给出结论。若 $p_{n,i} = \lambda/n$，总方差 $\sigma_n^2 = \lambda(1-\lambda/n) \to \lambda$ 有界：定义 1.8 的假设 $s_n \to \infty$ 不成立，上述论证均不适用，而极限为 Poisson(λ)——见习题 1.33，或带速率的定理 2.10。

1.22（B）

> 只要没有概率质量逃向无穷远，弱收敛在趋于恒等映射的仿射变换下保持。一致二阶矩界正是排除质量逃逸的条件。

工具。令 f 有界且一致连续，其连续模为 ω_f，并令 $\delta_n = |a_n - 1|M + |b_n|$。在 $\{|Z_n| \le M\}$ 上两个自变量相差至多 δ_n，故被积项相差至多 $\omega_f(\delta_n)$；在该事件之外用 $2\|f\|_\infty$ 作界，并用 $\mathbb{P}(|Z_n| > M) \le \mathbb{E}Z_n^2/M^2 \le C/M^2$。因此

$$|\mathbb{E}f(a_nZ_n + b_n) - \mathbb{E}f(Z_n)| \le \omega_f(\delta_n) + \frac{2\|f\|_\infty C}{M^2}.$$

固定 M 令 $n \to \infty$，再令 $M \to \infty$：左边趋零；由假设 $\mathbb{E}f(Z_n) \to \mathbb{E}f(Z)$。

应用。令 $Z_n = (R_n - H_n)/s_n$，满足 $\mathbb{E}Z_n^2 = 1$，则

$$\frac{R_n - \log n}{\sqrt{\log n}} = \frac{s_n}{\sqrt{\log n}}Z_n + \frac{H_n - \log n}{\sqrt{\log n}}.$$

又 $s_n^2/\log n = (H_n - \sum_{i\le n} i^{-2})/\log n \to 1$，而 $H_n - \log n \to \gamma$，故第二项的分子有界。由定理 1.17 和上述工具得到所求结论。

为何引理 1.2 不足。引理 1.2 将针对一个固定测试函数族的收敛推广。这里需要控制

$$\mathbb{E}f(a_nZ_n + b_n) = \mathbb{E}f_n(Z_n),$$

其中测试函数 f_n 随 n 变化；对每个固定 f 的收敛并不能直接说明这一点。一致二阶矩界填补了这一缺口。

1.23（B） 每个选择序列 $(c_1, \dots, c_n)$，$c_i \in \{1, \dots, i\}$，的概率都是 $\prod_{i\le n}(1/i) = 1/n!$，且共有 $n!$ 个。到排列的映射是单射：从最终排列的循环中删去 n 并读出它的操作，再递归。因此它是到 S_n 的双射，构造产生均匀分布。元素 i 恰在选中特定选项时开启新循环，概率为 $1/i$，且各次选择按构造独立。所以 K_n 与独立随机变量之和 $\sum_{i\le n}\mathrm{Bernoulli}(1/i)$ 同分布，即定理 1.17 的数组；习题 1.22 给出以 $\log n$ 为中心化项的结论。

初始化时的宽网络（第 1.8* 节）

1.25（B） $\mathbb{E}V_j = \mathbb{E}[a_j]\mathbb{E}[\sigma(\langle w_j, x_i\rangle)] = 0$：$a_j$ 与 w_j 独立使期望可以分解，而 $\mathbb{E}a_j = 0$ 使其为零。同理，

$$\mathrm{Cov}(V_j)_{il} = \mathbb{E}[a_j^2]\mathbb{E}[\sigma(\langle w_j, x_i\rangle)\sigma(\langle w_j, x_l\rangle)] = K(x_i, x_l),$$

其中用相同方式分解并使用 $\mathbb{E}a_j^2 = \sigma_a^2$。由于 (a_j, w_j) 独立同分布，V_j 也是；由定义

$$(f_m(x_1), \dots, f_m(x_k)) = m^{-1/2}\sum_j V_j.$$

多维中心极限定理只需二阶矩便适用。第二条路线更初等，但假设更强：对固定 $\xi \in \mathbb{R}^k$，将定理 1.7 应用于标量 $\langle \xi, V_j\rangle$ 得

$$\left\langle \xi, m^{-1/2}\sum_j V_j \right\rangle \Rightarrow \mathcal{N}(0, \xi^\top K\xi),$$

故对每个 ξ，$\varphi_{m^{-1/2}\sum_j V_j}(\xi)=\mathbb{E}[e^{-i\langle\xi,\cdot\rangle}]\to e^{-\xi^\top K\xi/2}$，再由引理 1.29 完成证明。但定理 1.7 假设 $\mathbb{E}|X_1|^3<\infty$，因此此路线需要三阶矩。

1.26（A） 有

$$\sum_{i,l} v_i v_l K(x_i,x_l)=\sigma_a^2\mathbb{E}\left[\left(\sum_i v_i\sigma(\langle w,x_i\rangle)\right)^2\right]\ge 0.$$

K 本身就是 V_j 的协方差，因此对 σ 除平方可积外无需其他条件。

1.27（C）

> $(\langle w,x\rangle,\langle w,x'\rangle)$ 是中心高斯对；由第 1–2 讲定理 1.5，其分布仅通过 2×2 Gram 矩阵依赖 x,x'。d 维积分实际上是二维的。

σ 正齐次，故 K 按 $\|x\|\|x'\|$ 缩放，可取 $\|x\|=\|x'\|=1$。这对投影是中心高斯，协方差为 $\begin{pmatrix}1&\cos\theta\\ \cos\theta&1\end{pmatrix}$，因此与 $(g_1,\cos\theta\, g_1+\sin\theta\, g_2)$ 同分布，其中 g_1,g_2 独立标准高斯。

写作 $(g_1,g_2)=R(\cos\alpha,\sin\alpha)$，其中 $R\ge 0$ 与均匀分布于 $[0,2\pi)$ 的 α 独立，$\mathbb{E}R^2=2$。于是该对为 $(R\cos\alpha, R\cos(\alpha-\theta))$，且

$$\begin{aligned}\mathbb{E}[\sigma\sigma']&=\mathbb{E}[R^2]\frac{1}{2\pi}\int_0^{2\pi}(\cos\alpha)_+(\cos(\alpha-\theta))_+\,d\alpha\\&=\frac{1}{\pi}\int_{\theta-\pi/2}^{\pi/2}\cos\alpha\cos(\alpha-\theta)\,d\alpha.\end{aligned}$$

被积函数恰在该区间为正，区间长度为 $\pi-\theta$。用 $\cos A\cos B=\frac12[\cos(A-B)+\cos(A+B)]$ 得

$$\begin{aligned}\int_{\theta-\pi/2}^{\pi/2}\cos\alpha\cos(\alpha-\theta)\,d\alpha&=\tfrac12(\pi-\theta)\cos\theta+\tfrac14\sin(2\alpha-\theta)\big|_{\theta-\pi/2}^{\pi/2}\\&=\tfrac12[(\pi-\theta)\cos\theta+\sin\theta],\end{aligned}$$

因为方括号之差为 $\sin\theta-(-\sin\theta)=2\sin\theta$。故值为 $[\sin\theta+(\pi-\theta)\cos\theta]/(2\pi)$。

检验：$\theta=0$ 时，$(2\pi)^{-1}\pi=1/2=\mathbb{E}[\max(0,g)^2]$；$\theta=\pi/2$ 时两投影独立，答案应为 $\mathbb{E}[\max(0,g)]^2=(2\pi)^{-1}$，结果确实如此。

未给出的证明（第 1.9* 节）

1.30（A） $t\mapsto e^{-itX}$ 的第 j 阶差商由 $|X|^j$ 控制，且 $j\le k$ 时它可积，因此可以在期望下对 $\varphi_X(t)=\mathbb{E}e^{-itX}$ 求 k 次导，得到因子 $(-iX)^k$。对 $\varphi=e^{-t^2/2}$，有 $\varphi'=-t\varphi$、$\varphi''=(t^2-1)\varphi$，故 $\varphi''(0)=-1=(-i)^2\mathbb{E}g^2$。级数 $e^{-t^2/2}=1-t^2/2+t^4/8-\cdots$ 中 t^4 的系数为 $1/8$，所以 $\varphi^{(4)}(0)=4!/8=3=(-i)^4\mathbb{E}g^4$。

1.32（B） 令 $a=1+z_n/n$、$b=e^{z_n/n}$，二者均为 $1+O(1/n)$，故存在固定 M 使 $|a|,|b|\le M$，且 $|a-b|=O(1/n^2)$；于是[1]

$$|a^n-b^n|\le nM^{n-1}|a-b|\longrightarrow 0,\qquad b^n=e^{z_n}\longrightarrow e^{z}.$$

由引理 1.31 对 $z_n=n(\varphi_{X_1}(t/\sqrt{n})-1)\to -t^2/2$ 应用上述结果，得 $\varphi_{S_n}(t)\to e^{-t^2/2}$，再由引理 1.29 完成。独立性给出 $\varphi_{S_n}=\prod_i\varphi_{X_i}(t/\sqrt{n})$；同分布只用于把同一因子写 n 次。

1.33（A） $\varphi_B(t)=(1-p)+pe^{-it}=1+p(e^{-it}-1)$，故由习题 1.32，

$$\varphi_{N_n}=\left[1+\frac{\lambda}{n}(e^{-it}-1)\right]^n\longrightarrow\exp(\lambda(e^{-it}-1)),$$

而 $\sum_k e^{-\lambda}(\lambda^k/k!)e^{-itk}=e^{-\lambda}e^{\lambda e^{-it}}$ 正是同一表达式。

1.34（B） $X_{n,i}$ 以概率 λ/n 取 $1-\lambda/n$，否则取 $-\lambda/n$，因此 $s_n^2=n(\lambda/n)(1-\lambda/n)=\lambda(1-\lambda/n)$。当 $\epsilon<1/\sqrt{\lambda}$，阈值 $\epsilon s_n\to\epsilon\sqrt{\lambda}<1$ 最终小于大值，故 $L_n(\epsilon)\to n(\lambda/n)(1/\lambda)=1$。当 $\lambda=3$、$\epsilon=1/2$：$n=10$ 时 $s_n=1.449$、$\epsilon s_n=0.7246$，而大值 $1-3/10=0.7<0.7246$，没有项被捕获，所以恰有 $L_{10}=0$；之后分别为 0.970 和 1.000。

1.35（C）

> 高斯特征函数 $e^{-\sigma^2t^2/2}$ 从不为零，弱收敛迫使变换收敛。因此一个零点即可排除所有高斯极限，无需知道极限存在。

$s_n^2=n\cdot 1+n=2n$。当且仅当 $\epsilon<1/\sqrt{2}$ 时，大项满足 $|X_{n,n+1}|=\sqrt{n}>\epsilon\sqrt{2n}=\epsilon s_n$，它独自对 L_n 贡献 $n/(2n)=1/2$。前 n 项满足 $s_n^{-1}\sum_{i\le n}X_{n,i}\Rightarrow\mathcal{N}(0,1/2)$，变换为 $e^{-t^2/4}$；最后一项为 $\pm1/\sqrt{2}$，变换为 $\cos(t/\sqrt{2})$。二者独立，故 $\varphi_n(t)\to e^{-t^2/4}\cos(t/\sqrt{2})$，在 $t=\pi/\sqrt{2}$ 为零。若 $s_n^{-1}\sum_i X_{n,i}\Rightarrow\mathcal{N}(0,\sigma^2)$，由 $e^{-it\cdot}$ 有界连续，对每个 t 必有 $\varphi_n(t)\to e^{-\sigma^2t^2/2}$；在 $t=\pi/\sqrt{2}$ 这不可能。

1.36（C）

> S_n 有原子。跳跃大小为 a 的分布函数与任何连续函数的距离至少为 $a/2$。

若 $F(z_0)-F(z_0^-)=a$ 且 Φ 连续，则 $|F(z_0)-\Phi(z_0)|+|F(z_0^-)-\Phi(z_0)|\ge a$，故上确界至少为 $a/2$。对 $X_i=\pm1$ 且 n 为偶数，$\mathbb{P}(S_n=0)=\binom{n}{n/2}2^{-n}\sim\sqrt{2/(\pi n)}$，故

$$\sup_z|\mathbb{P}(S_n\le z)-\Phi(z)|\ge cn^{-1/2}.$$

格点求和项在第 1.6 节收敛最慢正是因为其原子无法被平滑，且与整个误差预算同阶。

[1] 固定 $M>1$ 时 $nM^{n-1}O(n^{-2})$ 未必趋零。这里实际上可取 $M_n\le 1+C/n$，故 $M_n^{n-1}\le e^C$ 一致有界，差为 $O(n^{-1})$，补足原提示缺少的控制。

1.37（C）

> 将 $1-\varphi_Y$ 与 $1-\sin x/x$ 比较；后者处处非负，且在 $|x|\ge 2$ 时至少为 $1/2$。

由于 $\varphi_Y(-t)=\overline{\varphi_Y(t)}$，积分为实数。由 Fubini 定理（被积函数在有界区间上以 1 为界），

$$\int_{-u}^{u}\varphi_Y(t)\,dt=\mathbb{E}\int_{-u}^{u}e^{-itY}\,dt=\mathbb{E}\left[\frac{2\sin(uY)}{Y}\right],$$

因此

$$\frac{1}{u}\int_{-u}^{u}(1-\varphi_Y(t))\,dt=2\mathbb{E}\left[1-\frac{\sin(uY)}{uY}\right].$$

由 $|\sin x|\le|x|$，方括号非负；当 $|uY|\ge 2$ 时，由 $|\sin x/x|\le 1/|x|$，它至少为 $1/2$。故右侧至少为 $2\cdot\frac{1}{2}\mathbb{P}(|uY|\ge 2)=\mathbb{P}(|Y|\ge 2/u)$。

为证紧性，$\psi(0)=\lim_n\varphi_{Y_n}(0)=1$，故由 ψ 在 0 处连续，对任意 $\epsilon>0$ 存在 $u>0$ 使 $u^{-1}\int_{-u}^{u}(1-\psi)<\epsilon/2$。被积函数以 2 为界，控制收敛给出

$$\frac{1}{u}\int_{-u}^{u}(1-\varphi_{Y_n})\longrightarrow\frac{1}{u}\int_{-u}^{u}(1-\psi),$$

因此对所有 $n\ge N$，$\mathbb{P}(|Y_n|\ge 2/u)<\epsilon$。增大 K 使其超过 $2/u$ 即可照顾剩余有限多个 n。

刻画（第 2.1 节）

2.3（B）

> 两边都是 $\widehat{f}$ 对高斯变换的积分。在变换侧乘以 X_j 相当于对 ξ 求导，而高斯变换的导数是它自身乘以因子 $-(\Sigma\xi)_j$；两个被积函数因此相等。没有求逆，故 Σ 可以奇异。

(a) 令 $\psi(\xi)=\mathbb{E}[e^{i\langle X,\xi\rangle}]$，由第 1–2 讲定义 1.3，对每个 $\Sigma\succeq 0$ 它等于 $e^{-\xi^\top\Sigma\xi/2}$。由傅里叶反演 $f(x)=(2\pi)^{-d}\int\widehat{f}(\xi)e^{i\langle x,\xi\rangle}d\xi$，且 $\mathbb{E}\int|\widehat{f}(\xi)X_j|d\xi=\mathbb{E}|X_j|\,\|\widehat{f}\|_{L^1}<\infty$，Fubini 定理给出

$$\mathbb{E}[X_jf(X)]=\frac{1}{(2\pi)^d}\int\widehat{f}(\xi)\mathbb{E}[X_je^{i\langle X,\xi\rangle}]\,d\xi.$$

在期望下求导得 $\partial_{\xi_j}\psi(\xi)=\mathbb{E}[iX_je^{i\langle X,\xi\rangle}]$，对 ψ 的公式求导则得 $\partial_{\xi_j}\psi(\xi)=-(\Sigma\xi)_j\psi(\xi)$。故 $\mathbb{E}[X_je^{i\langle X,\xi\rangle}]=i(\Sigma\xi)_j\psi(\xi)$。

由于 $\xi_k\widehat{f}\in L^1$，由 $\widehat{\partial_kf}=i\xi_k\widehat{f}$ 可以反演出 ∂_kf，同样用 Fubini 定理得到

$$\mathbb{E}[\partial_kf(X)]=\frac{1}{(2\pi)^d}\int i\xi_k\widehat{f}(\xi)\psi(\xi)\,d\xi.$$

乘以 Σ_{jk} 并对 k 求和，被积函数变为 $i(\Sigma\xi)_j\widehat{f}(\xi)\psi(\xi)$，与第一个公式相同。这里只使用 $\psi(\xi)=e^{-\xi^\top\Sigma\xi/2}$，没有出现 Σ 的平方根或逆矩阵，退化情形无需另作处理。

(b) 固定 v，取 $F(x)=vf(\langle v,x\rangle)$，其中 $f\in C^1$ 且 f,f' 有界。令 $Y=\langle v,W\rangle$，则 $\langle W,F(W)\rangle=Yf(Y)$，$DF(x)=f'(\langle v,x\rangle)vv^\top$，故 $\operatorname{tr}(\Sigma DF)=\sigma^2f'(Y)$，其中 $\sigma^2=v^\top\Sigma v$。假设变为 $\mathbb{E}[Yf(Y)]=\sigma^2\mathbb{E}[f'(Y)]$。$\sigma>0$ 时，这就是应用于 Y/σ 的定理 2.1，故 $Y\sim\mathcal{N}(0,\sigma^2)$；$\sigma=0$ 时取允许的 $f(y)=y/(1+y^2)$，得到 $\mathbb{E}[Y^2/(1+Y^2)]=0$，因而 $Y=0$。W 的每个线性泛函都高斯，故由第 1–2 讲推论 1.7，$W\sim\mathcal{N}(0,\Sigma)$。

(c) 对指标集 $\{(k,l)\}$ 应用习题 2.3(a)：矩阵就是指标为二元组的向量，其协方差为 $\Sigma_{(ij),(kl)} = \mathbb{E}[M_{ij}M_{kl}]$。该论证没有用到指标集的形状。

独立性用在何处（第 2.5* 节）

2.13（A） 由可交换性，$\mathbb{E}F(W,W') = \mathbb{E}F(W',W)$，而由反对称性它又等于 $-\mathbb{E}F(W,W')$，因此为零。

2.14（B） $F(x,y) = (y-x)(f(x)+f(y))$ 反对称，故 $\mathbb{E}[(W'-W)(f(W)+f(W'))] = 0$。写作 $f(W') = f(W) + (W'-W)f'(W) + R$，其中 $|R| \le \|f''\|_\infty (W'-W)^2/2$，则

$$0 = 2\mathbb{E}[(W'-W)f(W)] + \mathbb{E}[(W'-W)^2 f'(W)] + \mathbb{E}[(W'-W)R].$$

由 Stein 对性质和对 W 条件化，第一项为 $-2a\mathbb{E}[Wf(W)]$。移项即得题中公式，余项的界为

$$\frac{\|f''\|_\infty}{4a}\mathbb{E}|W'-W|^3.$$

2.15（B） 交换 $X_I \leftrightarrow X_I'$ 保测，故 (W,W') 可交换。由于 $\mathbb{E}[X_I' \mid X_1,\dots,X_n] = 0$ 和 $\mathbb{E}[X_I \mid X_1,\dots,X_n] = n^{-1}\sum_i X_i$，

$$\mathbb{E}[W'-W \mid X_1,\dots,X_n] = -\frac{1}{\sqrt{n}}\frac{1}{n}\sum_i X_i = -W/n,$$

塔式性质给出 $a = 1/n$。又 $(W'-W)^2 = (X_I - X_I')^2/n$，其条件期望为 $n^{-2}\sum_i (X_i^2+1)$。除以 $2a = 2/n$ 得 $\frac{1}{2}(1 + n^{-1}\sum_i X_i^2)$；它与 1 的距离为 $\frac{1}{2}|1 - n^{-1}\sum_i X_i^2|$，在 L^1 中至多为 $\frac{1}{2}\sqrt{\mathrm{Var}(X_1^2)/n}$。余项为 $n\|f''\|_\infty n^{-3/2}\mathbb{E}|X_1 - X_1'|^3/4$。二者均为 $O(n^{-1/2})$。

独立性用在何处：用在两个条件期望中，而没有用在别处。乘积公式

$$\mathbb{E}[X_i f(W^{(i)})] = \mathbb{E}[X_i]\mathbb{E}[f(W^{(i)})]$$

从未出现。

译注： 原文说独立性仅用于两个条件期望，尚漏了上面对 $n^{-1}\sum_i X_i^2$ 的方差计算：独立性使平方变量的交叉协方差消失，从而得到 $\mathrm{Var}(X_1^2)/n$。

2.16（A） $\mathbb{E}W = n\cdot(1/n) = 1$；$i \ne j$ 时 $\mathbb{E}[I_iI_j] = 1/[n(n-1)]$，故 $\mathbb{E}W^2 = 1+1 = 2$、$\mathrm{Var}\,W = 1$。而 $\mathbb{P}(I_1 = I_2 = 1) = 1/[n(n-1)] \ne 1/n^2$。不成立的是定理 2.10 要求的 I_i 的独立性；因此该定理在此没有结论，假设不满足时即便得出真结论也不构成证明。

2.17（C）

复合以把 i 送到自身的换位，强制 i 成为不动点：$\sigma = \pi \circ (i\ \pi^{-1}(i))$。

于是 $\sigma(i)=\pi(\pi^{-1}(i))=i$；该映射是从 $\{\pi:\pi(i)\neq i\}$ 到其自身再经重新标记的双射，因此 σ 在固定 i 的排列中均匀。[2]写 $j=\pi^{-1}(i)$：i 成为不动点（增加 1），而当且仅当 $\pi(i)=j$，即 π 在 i 处有一个 2-循环时，j 也成为不动点（增加 2）。因此 $V_i=W(\sigma)-1\in\{W,W+1\}$[3]，且

$$\mathbb{E}|W-V_i|\le\mathbb{P}(\pi(i)=i)+\mathbb{P}(i\text{ 处有 2-循环})=\frac{1}{n}+\frac{1}{n}.$$

以 $p_i=1/n$、$\lambda=1$ 应用 Chen–Stein 方法，得到 $d_{\mathrm{TV}}(W,\mathrm{Poisson}(1))\le n\cdot(1/n)\cdot(2/n)=2/n$。

$n=10$ 时该界为 0.2，真实值为 2.3×10^{-8}，相差约七个数量级。

译注：2.3×10^{-8} 是单一事件 $|\mathbb{P}(W=0)-e^{-1}|$，不是全变差真值。由 $\mathbb{P}(W=k)=\frac{1}{k!}\sum_{j=0}^{n-k}(-1)^j/j!$ 并计入 Poisson 尾项，$n=10$ 的全变差约为 $2.1953510205\times10^{-5}$；与 0.2 相比约差四个数量级。原数值句作为单事件比较保留，Stein 上界本身仍有效。

它相对于容斥法的优点是稳健：除耦合之外，从未使用 π 是排列这一点；它也是本课程三条路线中唯一给出界的路线。

[2]原文双射说法不成立。每个固定 i 的目标排列 σ，在整个 S_n 中有 n 个原像 $\sigma\circ(i\ j)$，$j=1,\dots,n$；若只取 $\pi(i)\neq i$ 的域，则有 $n-1$ 个原像。各纤维等大，足以证明目标分布均匀。

[3]原文此集合漏掉 i 原本就是不动点的情形；此时 $\sigma=\pi$ 且 $V_i=W-1$。



现代机器学习中的概率

ORF 526 课程材料译稿

第 5–8 讲：Wick 定理与半圆律（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 Wick 定理与高斯随机矩阵

第 5–8 讲：Wick 定理与半圆律
配对划分、路径计数与 Stieltjes 变换。

纲要： 第 5 讲：Wick 定理 $\longrightarrow$ 高斯 Wigner 矩阵 $\longrightarrow$ 固定方向的 $\|Mu\|^2$。
第 6 讲：半圆律 $\longrightarrow$ 策略 $\longrightarrow$ 手算 $\mathbb{E}\,\mathrm{tr}\,M^2$、$\mathbb{E}\,\mathrm{tr}\,M^4$ $\longrightarrow$ 迹是路径之和 $\longrightarrow$ 用路径计算同样的两个矩 $\longrightarrow$ 所有矩。
第 7 讲：Stieltjes 变换 $\longrightarrow$ 用围道积分计数特征值 $\longrightarrow$ 要计算什么 $\longrightarrow$ $z=\infty$ 处的生成函数。
第 8 讲：Schur 补 $\longrightarrow$ 自洽方程 $\longrightarrow$ 迹的集中 $\longrightarrow$ 求解：半圆律。
阅读指南： 带星号的节不在课堂讲授，其内容完整、属于考试范围，并包含大多数习题。习题分为 A、B 两类，每讲三题。

问题： 不触及特征值，能计算随机矩阵的哪些性质？高斯向量的每个矩都是一个计数问题，而对称高斯矩阵的元素构成高斯向量。因此，矩阵元素的任何多项式——例如固定向量 u 所对应的 Mu 的长度——都能精确计算。

1.1 配对划分

定义 1.1 (配对划分)**.** $\{1,\dots,2q\}$ 的配对划分是将其划分为 q 个大小为 2 的块。

定理 1.2 (Wick)**.** 设 $X\sim\mathcal{N}(0,\Sigma)$ 取值于 $\mathbb{R}^d$，且 $a_1,\dots,a_m\in\{1,\dots,d\}$。若 m 为奇数，则 $\mathbb{E}[X_{a_1}\cdots X_{a_m}]=0$。若 $m=2q$，则

$$\mathbb{E}[X_{a_1}X_{a_2}\cdots X_{a_{2q}}]=\sum_{\substack{P\text{ 为}\{1,\dots,2q\}\\ \text{的配对划分}}}\prod_{\{r,s\}\in P}\Sigma_{a_ra_s}.$$

证明. 由第 1–2 讲推论 1.7，X 的每个线性泛函都是一维高斯变量，因此 X 具有各阶矩，φ_X 无限可微，且其导数可在期望内计算。由于 $\partial_{\xi_j}e^{-i\langle x,\xi\rangle}=-ix_je^{-i\langle x,\xi\rangle}$，乘以 X_j 作用在变换上相当于 $i\partial_{\xi_j}$：

$$\mathbb{E}[X_{a_1}\cdots X_{a_m}]=i^m\,\partial_{\xi_{a_1}}\cdots\partial_{\xi_{a_m}}\varphi_X(\xi)\Big|_{\xi=0}. \tag{1}$$

由第 1–2 讲定义 1.3，$\varphi_X(\xi)=\exp(-\frac12\xi^\top\Sigma\xi)$——对每个 $\Sigma\succeq0$ 均成立，包括退化情形——求一次导数得

$$\partial_{\xi_i}\varphi_X(\xi)=-\sum_j\Sigma_{ij}\xi_j\varphi_X(\xi). \tag{2}$$

取式 (2) 中 $i=a_1$，对其施加 $\partial_{\xi_{a_2}}\cdots\partial_{\xi_{a_m}}$。因子 ξ_j 是线性的，Leibniz 公式给出两类项：所有导数均落在 φ_X 上、仍含因子 ξ_j 的项；以及对每个 $s\in\{2,\dots,m\}$，导数 $\partial_{\xi_{a_s}}$ 落在 ξ_j 上并产生 δ_{ja_s} 的项。取 $\xi=0$ 消去第一类，得到

$$\partial_{\xi_{a_1}}\cdots\partial_{\xi_{a_m}}\varphi_X\Big|_0=-\sum_{s=2}^{m}\Sigma_{a_1a_s}\,\partial_{\{\xi_{a_r}:r\neq1,s\}}\varphi_X\big|_0.$$

用式 (1) 改写两边并乘以 i^m；因为 $i^2=-1$，两个负号抵消，故

$$\mathbb{E}[X_{a_1}\cdots X_{a_m}] = \sum_{s=2}^{m} \Sigma_{a_1 a_s}\, \mathbb{E}\left[\prod_{r\neq 1,s} X_{a_r}\right]. \tag{3}$$

即将第一个因子依次与其余各因子配对，并递归。对 m 归纳：$m=1$ 时两边均为零，$m=2$ 时结论就是 Σ 的定义。对 $m>2$，式 (3) 将因子数减去 2，故保持奇偶性：奇数个因子的乘积化为 $\mathbb{E}[X_a]=0$；偶数个因子的乘积化为对剩余 $2q-2$ 个指标的配对划分求和，每项前乘以记录含 1 的块的 $\Sigma_{a_1a_s}$。对 s 求和恰好将 $\{1,\dots,2q\}$ 的每个配对划分枚举一次。 □

注 1.3. 在式 (3) 中取 $F(X)=X_{a_2}\cdots X_{a_m}$，并注意 $\partial_j F$ 删去因子 X_j，得到

$$\mathbb{E}[X_i F(X)] = \sum_j \Sigma_{ij}\,\mathbb{E}[\partial_j F(X)],$$

即高斯分部积分。当 $d=1$、$\Sigma=1$ 时，这就是 $\mathbb{E}[gF(g)]=\mathbb{E}[F'(g)]$——第 1–2 讲引理 1.10，以及第 4 讲的 Stein 引理。这是第 3–4 讲习题 2.3；此处它作为 Wick 递推的直接结果出现。

1.2 三个例子

推论 1.4. $2q$ 个点的配对划分有 $(2q-1)!! = (2q-1)(2q-3)\cdots 3\cdot 1$ 个；对 $g\sim\mathcal{N}(0,1)$，$\mathbb{E}[g^{2q}]=(2q-1)!!$。

证明. 在定理 1.2 中取 $d=1$、$\Sigma=1$：每个协方差乘积都等于 1，所以该矩等于配对划分数。该数目为 $(2q-1)!!$，因为点 1 有 $2q-1$ 种选择配对对象的方法，删除该块后剩下 $2q-2$ 个点。 □

例 1.5 (四个指标)**.** 当 $q=2$ 时，$\{1,2,3,4\}$ 的三个配对划分为 $\{12\}\{34\}$、$\{13\}\{24\}$、$\{14\}\{23\}$，因此

$$\mathbb{E}[X_1X_2X_3X_4] = \Sigma_{12}\Sigma_{34}+\Sigma_{13}\Sigma_{24}+\Sigma_{14}\Sigma_{23}.$$

将四个指标都取相同，得到 $\mathbb{E}[X_1^4]=3\Sigma_{11}^2$。

例 1.6 (二次型)**.** 设 $X\sim\mathcal{N}(0,\Sigma)$ 取值于 $\mathbb{R}^d$，A 对称。则 $\mathbb{E}[X^\top AX]=\sum_{ij}A_{ij}\mathbb{E}[X_iX_j]=\operatorname{tr}(A\Sigma)$，无需 Wick 定理。对于二阶矩，由例 1.5，

$$\begin{aligned}\mathbb{E}[(X^\top AX)^2] &= \sum_{ijkl} A_{ij}A_{kl}\,\mathbb{E}[X_iX_jX_kX_l]\\ &= \sum_{ijkl} A_{ij}A_{kl}(\Sigma_{ij}\Sigma_{kl}+\Sigma_{ik}\Sigma_{jl}+\Sigma_{il}\Sigma_{jk}).\end{aligned}$$

第一项为 $(\operatorname{tr}A\Sigma)^2$；由于 A,Σ 对称，另两项各为 $\operatorname{tr}(A\Sigma A\Sigma)$。因此

$$\operatorname{Var}(X^\top AX) = 2\operatorname{tr}((A\Sigma)^2), \qquad \text{特别地}\quad \operatorname{Var}(\|X\|^2)=2\operatorname{tr}(\Sigma^2).$$

1.3 高斯 Wigner 矩阵

定义 1.7 (高斯 Wigner 矩阵)**.** 设 A 为 $N\times N$ 矩阵，元素独立同分布于 $\mathcal{N}(0,1)$，令

$$M=\frac{1}{\sqrt{2N}}(A+A^{\top}).$$

则 M 对称，其元素 $\{M_{ij}\}_{i\le j}$ 是独立的中心高斯变量，$i<j$ 时 $\mathbb{E}M_{ij}^2=1/N$，且 $\mathbb{E}M_{ii}^2=2/N$；对任意四个指标，

$$\mathbb{E}[M_{ij}M_{kl}]=\frac{1}{N}(\delta_{ik}\delta_{jl}+\delta_{il}\delta_{jk}). \tag{4}$$

这一系综称为高斯正交系综，简称 GOE，原因见注 1.8。下文的一切均来自式 (4) 和定理 1.2；该构造本身不再出现。两个 δ 项对应将 $\{i,j\}$ 与 $\{k,l\}$ 匹配的两种方式；它们出现是因为 $M_{ij}=M_{ji}$，同一元素可能以两个名字出现。对角方差 $2/N$ 源于对称化（习题 1.9），且它恰使式 (4) 在 $i=j=k=l$ 时无需特殊处理也成立。N 个对角元素在 N^2 个元素中所占比例趋于零。

注 1.8 (为何称为“正交”)**.** 对任意固定正交矩阵 O，$OAO^{\top}$ 的元素仍独立同分布于 $\mathcal{N}(0,1)$——每个元素都是 A 的单位线性泛函，而第 1–2 讲定理 1.5 保证整个集合联合高斯且协方差不变——因此 $OMO^{\top}\overset{d}{=}M$。谱的分布因而不能依赖基底。这是第 1–2 讲推论 1.6 的旋转不变性的矩阵形式。

习题 1.9 (A 类)**.** 从构造验证定义 1.7：设 A 的元素独立同分布于 $\mathcal{N}(0,1)$，$M=(A+A^{\top})/\sqrt{2N}$，直接计算 $\mathbb{E}[M_{ij}M_{kl}]$ 并得到式 (4)。单独检验 $i=j=k=l$ 的情形，确认对角约定 $\mathbb{E}M_{ii}^2=2/N$ 是必然的，而不是选定的。

1.4 每次看一个方向

在讨论特征值之前，先问一个形状相同但不含线性代数的问题：固定单位向量 u，问 Mu 有多长。

命题 1.10. 设 M 如定义 1.7，$u\in\mathbb{R}^N$ 且 $\|u\|=1$。则 Mu 是中心高斯向量，其协方差为

$$C=\mathbb{E}[(Mu)(Mu)^{\top}]=\frac{1}{N}(I+uu^{\top}),$$

因而

$$\mathbb{E}\|Mu\|^2=1+\frac{1}{N},\qquad \operatorname{Var}(\|Mu\|^2)=\frac{2}{N}+\frac{6}{N^2}.$$

证明. 每个坐标 $(Mu)_i=\sum_j M_{ij}u_j$ 都是 M 的元素的线性泛函，故由第 1–2 讲定理 1.5，向量 Mu 是中心高斯的。将式 (4) 与 u 缩并两次，得到协方差

$$\mathbb{E}[(Mu)_i(Mu)_k]=\sum_{j,l}u_ju_l\frac{1}{N}(\delta_{ik}\delta_{jl}+\delta_{il}\delta_{jk})=\frac{1}{N}(\delta_{ik}\|u\|^2+u_iu_k),$$

这就是 C。于是 $\mathbb{E}\|Mu\|^2=\operatorname{tr}C=(N+1)/N$。对方差，在例 1.6 中取 $A=I$、$\Sigma=C$，得 $\operatorname{Var}(\|Mu\|^2)=2\operatorname{tr}C^2$；由于 $u^{\top}u=1$，

$$(I+uu^{\top})^2=I+2uu^{\top}+u(u^{\top}u)u^{\top}=I+3uu^{\top},\qquad \operatorname{tr}C^2=\frac{1}{N^2}(N+3).$$

□

注 1.11. 可读出两点。第一，答案不依赖于 u——它不可能依赖，因为由注 1.8 有 $OMO^\top \overset{d}{=} M$，所以 $\|Mu\|^2$ 在每个方向上的分布相同。第二，标准差为 $\sqrt{2/N}$ 的量级，而均值为 1：当 N 很大时，高斯 Wigner 矩阵将每个单位向量映到长度非常接近 1 的向量。这已经是关于特征值的陈述，因为 $\|Mu\|^2 = u^\top M^2 u$ 是各 λ_i^2 的加权平均，权重 $\langle u, \phi_i\rangle^2$ 之和为 1，其中 ϕ_i 是特征向量。改为对方向求平均，而不是固定一个方向，可得到 $N^{-1}\operatorname{tr} M^2$，第 2.3 节将讨论它。

译注： 上述命题对每个预先固定、与 M 独立的确定性 u 给出集中；不能交换量词，推成同一个矩阵同时使所有单位方向近等长，也不适用于依赖 M 选出的特征向量。全方向近等距还会与半圆律中接近 0 及模大于 1 的特征值矛盾。

1.5 * 累积量

本节不在课堂讲授。定理 1.2 是适用于任何具有各阶矩的随机向量的公式的高斯特例。本节陈述该公式；习题推导使其有用的性质。

定义 1.12 (联合累积量)**.** 对各阶矩有限的 $Y_1, \dots, Y_m$，

$$\kappa(Y_1, \dots, Y_m) = \frac{\partial^m}{\partial t_1 \cdots \partial t_m} \log \mathbb{E}[e^{t_1 Y_1 + \cdots + t_m Y_m}]\Big|_{t=0}.$$

矩是变换的导数，累积量是变换的对数的导数。单个变量的第 m 阶累积量为 $\kappa(Y, \dots, Y)$，有 m 个参数；当参数本身是一个和时，保留这 m 个位置才能使用多线性。

译注： 实对数矩母函数的导数定义需要矩母函数在 0 的某个邻域有限；各阶矩有限并不足够。例如 $Y = e^Z$（Z 标准高斯）各阶矩均有限，但 $\mathbb{E}e^{tY} = \infty$ 对所有 $t > 0$ 成立。也可另用矩的有限阶形式递推定义累积量，但须明确区分。后面的任意 m 阶陈述要求相应矩 / 累积量存在，仅均值、方差有限不能保证三阶以上量有定义。

不加证明地陈述：矩–累积量公式

对任意具有各阶矩的 $Y_1, \dots, Y_m$，

$$\mathbb{E}[Y_1 Y_2 \cdots Y_m] = \sum_{\pi \in \mathcal{P}(m)} \prod_{B \in \pi} \kappa(Y_i : i \in B),$$

其中 $\mathcal{P}(m)$ 是将 $\{1, \dots, m\}$ 划分为非空块的所有划分之集合，其数目依次为 $1, 2, 5, 15, 52, \dots$。

当 $m = 2$ 时，这就是 $\mathbb{E}[Y_1 Y_2] = \mathbb{E}Y_1 \mathbb{E}Y_2 + \operatorname{Cov}(Y_1, Y_2)$，对应 $\{1, 2\}$ 的两个划分。若各 Y_i 为中心高斯向量的坐标，所有不为二阶的联合累积量均为零（习题 1.14），因此除非每个块大小都为 2，否则划分没有贡献。这些就是配对划分，矩–累积量公式便成为定理 1.2。四元素集合的 15 个划分中有 3 个存留下来，即例 1.5。

注 1.13. 对于非高斯向量，更大的块不消失，$\log \mathbb{E}[e^{\langle t, X\rangle}]$ 不再是多项式，而递推式 (3) 获得一个永不终止的尾项。累积量于是度量与高斯分布的距离；而由于独立变量的混合累积量为零，它们是记录独立变量之和的自然工具。

习题 1.14 (B 类)**.** 直接从定义 1.12 证明以下性质。

(a) 多线性。κ 对参数对称且对每个参数线性；当 $m \geq 2$ 时，对任一参数加常数不改变它。特别地，$\kappa(cY,\dots,cY) = c^m \kappa(Y,\dots,Y)$。

(b) 独立性。若参数可分成彼此独立的两个非空组，则累积量为零。推得对独立的 Y, Z，$\kappa(Y+Z,\dots,Y+Z) = \kappa(Y,\dots,Y) + \kappa(Z,\dots,Z)$。

(c) 高斯分布使它们终止。对 $X \sim \mathcal{N}(0,\Sigma)$，$\kappa(X_a, X_b) = \Sigma_{ab}$，且每个不为二阶的联合累积量均为零。

对 (a)，在对数变换中给两个变量分别设置参数 s, s'，并应用一次链式法则。对 (c)，在第 1–2 讲定义 1.3 中取 $\xi = it$。

习题 1.15 (B 类)**.** 设 $X_1, X_2, \dots$ 独立同分布，均值为 μ、方差为 σ^2，令 $S_n = n^{-1/2}\sum_{i=1}^{n}(X_i - \mu)$。只使用习题 1.14 的 (a)、(b) 两部分，证明对 $m \geq 2$，且每个累积量中均有 m 个参数时，

$$\kappa(S_n,\dots,S_n) = n^{1-m/2}\kappa(X_1,\dots,X_1).$$

推得对每个 n，$\kappa(S_n, S_n) = \sigma^2$，而每个三阶及以上的累积量趋于 0。

这是通过累积量看到的中心极限定理：$\sqrt{n}$ 归一化恰好固定二阶累积量，并消去其上所有阶。

第 5 讲指定作业，第 6 讲开始时交： 习题 1.9、1.14、1.15，共三题。第一题检查定义；另两题是课堂上来不及做的累积量计算。

2 半圆律

问题： 大型随机对称矩阵的特征值在哪里？其矩是归一化的迹。迹是对闭合路径求和，在主阶只有沿树行走的路径有贡献。将此类路径在每条边上的两步配对，得到非交叉配对划分，而其数量由 Catalan 数给出。

2.1 定理

回忆定义 1.7：$M = (A + A^{\top})/\sqrt{2N}$，其中 A 的元素独立同分布于 $\mathcal{N}(0,1)$，因此 M 对称，$\{M_{ij}\}_{i\leq j}$ 是独立的中心高斯变量，且

$$\mathbb{E}[M_{ij}M_{kl}] = \frac{1}{N}(\delta_{ik}\delta_{jl} + \delta_{il}\delta_{jk}), \qquad \text{特别地} \quad \mathbb{E}M_{ij}^2 = \frac{1}{N}\ (i \neq j), \qquad \mathbb{E}M_{ii}^2 = \frac{2}{N}.$$

M 有 N 个实特征值 $\lambda_1, \dots, \lambda_N$。图 1 给出其直方图。

定理 2.1 (Wigner)**.** 在 $[-2,2]$ 上令 $\rho_{\mathrm{sc}}(x) = \frac{1}{2\pi}\sqrt{4-x^2}$。对每个 $k \geq 0$，依概率有

$$\frac{1}{N}\sum_{i=1}^{N}\lambda_i^k \longrightarrow \int_{-2}^{2} x^k \rho_{\mathrm{sc}}(x)\,dx.$$

不加证明地陈述：矩方法

具有有界支撑的概率密度由其各阶矩确定。因此定理 2.1 蕴含，对每个有界连续函数 f，依概率有 $N^{-1}\sum_i f(\lambda_i) \to \int f\rho_{\mathrm{sc}}$：直方图收敛到 ρ_{sc}。

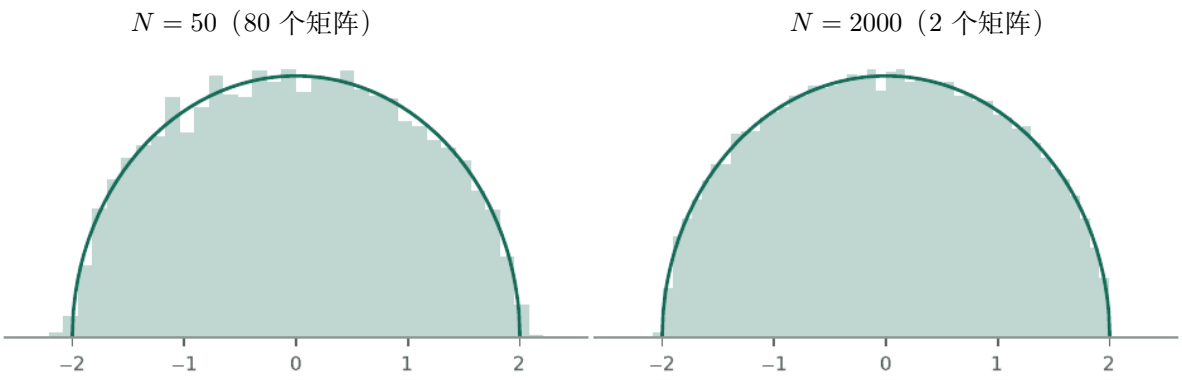


图 1: 高斯 Wigner 矩阵特征值的直方图，归一化使面积为 1，图中叠加曲线 $\frac{1}{2\pi}\sqrt{4-x^2}$。

2.2 策略

证明依托四个想法。

1. **矩收敛到矩**。若特征值具有密度为 ρ 的极限分布，意义为 $N^{-1}\sum_i f(\lambda_i) \to \int f\rho$，则取 $f(x) = x^k$，特征值的矩 $N^{-1}\sum_i \lambda_i^k$ 应当收敛到 ρ 的矩。而特征值的矩是迹（引理 2.2）。

2. **平均值是高斯计算加组合学**。$\operatorname{tr} M^k$ 是 M 的元素的多项式，因此定理 1.2 可计算 $\mathbb{E}\operatorname{tr} M^k$。剩下的是整理求和，这是一个计数问题（第 2.3–2.6 节）。

3. **涨落小**。若 $\operatorname{Var}(N^{-1}\operatorname{tr} M^k)/(N^{-1}\mathbb{E}\operatorname{tr} M^k)^2 \to 0$，则 Chebyshev 不等式将均值收敛转化为依概率收敛（第 2.7 节）。

4. **辨认极限**。均值的极限恰好是 Catalan 数，而它们是 ρ_{sc} 的矩（命题 2.17、习题 2.21）。

译注： 第 1 项是策略说明：弱收敛只直接控制有界连续检验函数，取无界 x^k 还需一致可积性 / 尾部控制或后文的直接矩估计。第 3 项的相对方差只在均值非零时可用；奇数高斯迹矩均值为 0，应使用绝对方差趋零，不能除以其平方。

引理 2.2. 对每个 $k \geq 1$，$N^{-1}\sum_{i=1}^N \lambda_i^k = N^{-1}\operatorname{tr} M^k$。

证明. 对角化：$M = O\Lambda O^\top$，其中 O 正交且 Λ 对角，于是 $M^k = O\Lambda^k O^\top$，由迹的循环性有 $\operatorname{tr} M^k = \operatorname{tr}\Lambda^k = \sum_i \lambda_i^k$。 □

注 2.3 (经验谱测度)**.** “极限分布” 是概率测度 $\widehat{\rho}_M = N^{-1}\sum_i \delta_{\lambda_i}$ 的极限，该测度在每个特征值处赋予质量 $1/N$。下面的论证从不需要它，而是直接使用数值 $N^{-1}\operatorname{tr} M^k$。第 7 讲也不需要它，那里研究的对象是函数 m_N，而密度通过围道积分得到。

2.3 手算两个矩

将命题 1.10 中 $\|Mu\|^2 = u^\top M^2 u$ 对一组正交基的向量取平均，得到第一个要计算的矩 $N^{-1}\operatorname{tr} M^2$。

命题 2.4. $\mathbb{E}\operatorname{tr} M^2 = N + 1$。

证明. $\operatorname{tr} M^2 = \sum_{i,j} M_{ij}M_{ji}$，式 (4) 给出 $\mathbb{E}[M_{ij}M_{ji}] = N^{-1}(\delta_{ij}\delta_{ji} + \delta_{ii}\delta_{jj}) = N^{-1}(1+\delta_{ij})$，故

$$\mathbb{E}\operatorname{tr} M^2 = \frac{1}{N}\sum_{i,j}(1+\delta_{ij}) = \frac{1}{N}(N^2+N) = N+1.$$

□

对于四阶矩，定理 1.2 给出四个因子的三个配对划分。

命题 2.5. $\mathbb{E}\operatorname{tr} M^4 = 2N + 5 + 5/N$。

证明. 展开 $\operatorname{tr} M^4 = \sum_{i,j,k,l} M_{ij}M_{jk}M_{kl}M_{li}$，定理 1.2 将每项分成四个因子的三个配对划分。依次处理。

配对 $\{12\}\{34\}$。由式 (4)，$\mathbb{E}[M_{ij}M_{jk}] = N^{-1}(\delta_{ij}\delta_{jk} + \delta_{ik})$，$\mathbb{E}[M_{kl}M_{li}] = N^{-1}(\delta_{kl}\delta_{li} + \delta_{ki})$。乘开得到四项；分别对 i,j,k,l 求和，就是计算各项允许的指标元组数目：

$$\underbrace{\delta_{ij}\delta_{jk}\delta_{kl}\delta_{li}}_{\text{全部相等：}\,N} + \underbrace{\delta_{ij}\delta_{jk}\delta_{ki}}_{i=j=k:\,N^2} + \underbrace{\delta_{ik}\delta_{kl}\delta_{li}}_{i=k=l:\,N^2} + \underbrace{\delta_{ik}}_{i=k:\,N^3}.$$

故贡献为 $N^{-2}(N^3 + 2N^2 + N) = N + 2 + N^{-1}$。

配对 $\{14\}\{23\}$。对 $\mathbb{E}[M_{ij}M_{li}] = N^{-1}(\delta_{il}\delta_{ij} + \delta_{jl})$ 和 $\mathbb{E}[M_{jk}M_{kl}] = N^{-1}(\delta_{jk}\delta_{kl} + \delta_{jl})$ 作相同计算，再次得到 $N + 2 + N^{-1}$。

配对 $\{13\}\{24\}$。此时

$$\mathbb{E}[M_{ij}M_{kl}]\mathbb{E}[M_{jk}M_{li}] = N^{-2}(\delta_{ik}\delta_{jl} + \delta_{il}\delta_{jk})(\delta_{jl}\delta_{ki} + \delta_{ji}\delta_{kl}),$$

其四项分别允许 N^2, N, N, N 个元组——第一项为 $\delta_{ik}\delta_{jl}$，有两个约束；其余三项各迫使四个指标全部相等。贡献为 $N^{-2}(N^2 + 3N) = 1 + 3/N$。相加得

$$\mathbb{E}\operatorname{tr} M^4 = 2(N + 2 + N^{-1}) + 1 + 3/N = 2N + 5 + 5/N.$$

□

除以 N 后，$N^{-1}\mathbb{E}\operatorname{tr} M^2 \to 1$，$N^{-1}\mathbb{E}\operatorname{tr} M^4 \to 2$。三个配对中两个以 N 阶贡献，第三个仅为 1 阶。本节其余部分解释哪些配对胜出，以及为什么。

习题 2.6 (A 类)**.** 不作计算证明对每个 $k \geq 0$ 都有 $\mathbb{E}\operatorname{tr} M^{2k+1} = 0$，并说明原因。然后计算 $\mathbb{E}[(\operatorname{tr} M)^2]$。

2.4 矩阵乘积是路径之和

对矩阵 A, B，$(AB)_{ij} = \sum_l A_{il}B_{lj}$：这是从 i 经某个 l 用两步走到 j 的所有方式之和，每条路径以所用元素之积加权。迭代便得到任意次幂的相同描述。

定义 2.7 (路径)**.** 从 i 到 j 的长度为 m 的路径是 $\{1,\dots,N\}$ 中的顶点序列

$$\pi = (\pi(0), \pi(1), \dots, \pi(m)), \qquad \pi(0) = i, \quad \pi(m) = j,$$

也记作 $\pi(0)\to\pi(1)\to\cdots\to\pi(m)$。若 $\pi(m)=\pi(0)$，则称其闭合。第 a 步从 $\pi(a-1)$ 到 $\pi(a)$，经过边 $\{\pi(a-1),\pi(a)\}$；若 $\pi(a-1)=\pi(a)$，该边是自环。其权重为

$$W(\pi)=\prod_{a=1}^{m} M_{\pi(a-1)\pi(a)}.$$

由于 $M_{ab}=M_{ba}$，边上的矩阵元素与经过方向无关。展开乘积，

$$(M^m)_{ij}=\sum_{\pi:i\to j} W(\pi),\qquad \mathbb{E}\,\mathrm{tr}\,M^m=\sum_{i=1}^{N}\sum_{\pi:i\to i}\mathbb{E}W(\pi),$$

内层求和分别遍及从 i 到 j 和从 i 回到 i 的长度为 m 的路径。记为

$$\mathbb{E}\,\mathrm{tr}\,M^m=\sum_{\substack{\pi\ \text{闭合}\\ \text{长度}m}}\mathbb{E}W(\pi). \tag{5}$$

引理 2.8. 设 π 为长度 m 的闭合路径。除非 π 经过每条边（包括自环）的次数均为偶数，否则 $\mathbb{E}W(\pi)=0$。无论何种情形，$|\mathbb{E}W(\pi)|\le c_m N^{-m/2}$，其中 c_m 只依赖于 m。

证明. 按边将 $W(\pi)$ 的因子分组。不同边上的矩阵元素独立，故 $\mathbb{E}W(\pi)=\prod_e \mathbb{E}[M_e^{n_e}]$，其中 n_e 是经过边 e 的次数，且 $\sum_e n_e=m$。中心高斯变量的奇数阶矩为零，并且 $|\mathbb{E}M_e^n|\le (2/N)^{n/2}\mathbb{E}|g|^n$。□

特别地，只有每条边至少经过两次的闭合路径对式 (5) 有贡献。

2.5 用路径计算同样的两个矩

$m=2$。长度为 2 的闭合路径形如 $i\to j\to i$：它往返各一次，共经过边 $\{i,j\}$ 两次。满足 $i\neq j$ 的路径共有 $N(N-1)$ 条，每条有 $\mathbb{E}M_{ij}^2=1/N$；另有 N 条自环，每条有 $\mathbb{E}M_{ii}^2=2/N$：再次得到 $\mathbb{E}\,\mathrm{tr}\,M^2=N-1+2=N+1$。

$m=4$。按形状分类那些长度为 4、每条边至少经过两次的闭合路径：

形状	例子	顶点数	贡献
一个顶点发出两条边	$i\to j\to i\to l\to i$	3	$N(N-1)(N-2)N^{-2}=N+O(1)$
沿一条路往返	$i\to j\to k\to j\to i$	3	$N(N-1)(N-2)N^{-2}=N+O(1)$
一条边经过四次	$i\to j\to i\to j\to i$	2	$N(N-1)\cdot 3N^{-2}=O(1)$
自环及其他重合		≤ 2	$O(1)$

前两种形状使用三个不同顶点和两条不同边，每条边恰经过两次，一次去、一次回；它们是 N 阶的贡献。它们描出的图是一棵树。第三种将一条边经过四次，只有两个顶点。

从路径到配对划分。对于每条边恰经过两次的路径，将经过同一条边的两步配对。$i\to j\to i\to l\to i$ 将第 1、2 步配对、第 3、4 步配对，得到划分 $\{12\}\{34\}$。$i\to j\to k\to j\to i$ 将第 2、3 步配对、第 1、4 步配对，得到 $\{14\}\{23\}$。这恰是命题 2.5 中以 N 阶贡献的两个配对。第三种配对 $\{13\}\{24\}$ 需要第 1、3 步处于一条边，第 2、4 步处于另一条边；在闭合路径 $i\to j\to k\to l\to i$ 中，这迫使 $i=k$、$j=l$，得到只有两个顶点的单边路径。区分它的是以下性质。

定义 2.9 (交叉)**.** 将配对划分的 $2q$ 个点画在一条直线上，用上方的弧连接每个块。若 $a<c<b<d$，则两块 $\{a,b\}$ 和 $\{c,d\}$ 交叉。没有交叉块的配对划分称为非交叉的；当点数分别为 2、4、6、8 时，这样的划分数为 $1,2,5,14,\ldots$，而配对划分总数分别为 $1,3,15,105$。

注 2.10 (交叉的代价)**.** N 阶的路径有三个顶点，而与交叉配对相容的路径只有两个。每个顶点是一个自由指标，价值一个因子 N。交叉配对失去一个顶点，也就失去一个 N 的幂次。

关于这一对应有两点提醒。第一，路径只在主阶决定其配对：单边路径 $i\to j\to i\to j\to i$ 将其边经过四次，所以定理 1.2 以所有三种方式配对各步，$\mathbb{E}M_{ij}^4=3(\mathbb{E}M_{ij}^2)^2$，没有唯一一个配对属于它。第二，“交叉”只指配对划分的弧；路径的各步经过的是边。

注 2.11 (实数与复数)**.** 式 (4) 中两个 δ 项来自 $M_{ij}=M_{ji}$。复 Hermitian 矩阵有 $\mathbb{E}[H_{ij}H_{kl}]=N^{-1}\delta_{il}\delta_{jk}$，只有一项而不是两项，于是交叉划分留下三个约束而非两个，其代价为 N^{-2}。将两个矩阵元素粘合在一起多出的一种方式，就是这两个系综的全部区别。

2.6 所有矩

奇数阶矩为零：$\mathbb{E}\operatorname{tr}M^{2k+1}=0$，因为奇数长度路径的权重是奇数个中心联合高斯变量的乘积。下面考虑偶数次幂 $2k$。

固定起始顶点。每条闭合路径都有起点，而且固定起点无需付出代价。

引理 2.12. 对每个顶点 i，

$$\frac{1}{N}\mathbb{E}\operatorname{tr}M^{2k}=\mathbb{E}(M^{2k})_{ii}=\sum_{\pi:i\to i}\mathbb{E}W(\pi).$$

证明. 对置换矩阵 Q，矩阵 $QMQ^{\top}$ 与 M 同分布（注 1.8），而 $(QM^{2k}Q^{\top})_{ii}$ 是 M^{2k} 的另一个对角元素。因此 M^{2k} 的全部 N 个对角元素同分布，其平均值 $N^{-1}\operatorname{tr}M^{2k}$ 与任意一个对角元素的均值相同。 □

固定起始顶点消去了因子 $1/N$，整个论证现变成顶点计数。由引理 2.8（取 $m=2k$），除非 π 每条边都经过偶数次，否则 $\mathbb{E}W(\pi)=0$，而总有 $|\mathbb{E}W(\pi)|\le c_{2k}N^{-k}$。

引理 2.13 (树是最稀疏的连通图)**.** 设 π 为从 i 出发回到 i、长度为 $2k$ 且每条边至少经过两次的路径，令 v 为其不同顶点的数量（包括 i）。则 $v\le k+1$，等号成立当且仅当经过的边构成一棵有 k 条边的树，且每条边恰好经过两次。

证明. 每条边至少占 $2k$ 步中的两步，故不同边至多 k 条。它们构成的图是连通的，因为一条路径经过其全部部分；而 v 个顶点的连通图至少有 $v-1$ 条非自环边，等号恰在其为树时成立。因此 $v\le k+1$；等号强制有 k 条不同边、没有自环，它们构成一棵树，每条边恰经过两次。 □

称等号情形的路径为树路径。删除树的一条边会使树断开，所以树上返回起点的路径沿每条边交替向两个方向经过：树路径的 k 条边每条均走出一次、走回一次。

命题 2.14 (只有树路径存留)**.** 令 $T_{k,N}$ 为从 i 出发、长度 $2k$ 的树路径数，则

$$\frac{1}{N}\mathbb{E}\operatorname{tr}M^{2k}=N^{-k}T_{k,N}+O\!\left(\frac{1}{N}\right).$$

证明. 按不同顶点数 v 分类路径 $\pi : i \to i$。由引理 2.8，只有每条边至少经过两次的路径有贡献；由引理 2.13，这些路径满足 $v \le k+1$。v 个顶点的路径至多有 $c_{k,v}N^{v-1}$ 条：记录时刻 $0, 1, \dots, 2k$ 中哪些访问同一顶点，这种模式至多有只依赖 k, v 的 $c_{k,v}$ 种；给定模式后，从 $N-1$ 个顶点中选择除 i 外的 $v-1$ 个顶点。

因此由引理 2.8，$v \le k$ 的路径总贡献至多为 $c_{k,v}N^{v-1} \cdot c_{2k}N^{-k} = O(1/N)$。$v = k+1$ 的路径是树路径。树没有自环，故树路径的 k 条边均连接两个不同顶点，携带方差 $1/N$ 的矩阵元素，且恰经过两次：$\mathbb{E}W(\pi) = N^{-k}$ 恰好成立。 □

剩下的是计数树路径，非交叉配对划分在此出现。树路径的配对将经过每条边的两步配对。

引理 2.15. 树路径的配对是非交叉的。反过来，对 $2k$ 步的每个非交叉配对划分，从 i 出发、以它为配对的树路径恰有 $(N-1)(N-2)\cdots(N-k)$ 条。

证明. 假设一条树路径的配对有交叉块 $\{a, b\}$ 与 $\{c, d\}$，其中 $a < c < b < d$，令 e 为第 a, b 步经过的边。在第 a 与第 b 步之间，路径位于 e 的远侧；第 b 步后则永远处于近侧，因为 e 只经过两次。因此第 c 步经过的边位于远侧，却在处于近侧的第 d 步再次经过，不可能。

反向对 k 归纳。$k = 1$ 时，树路径为 $i \to j \to i$，其中 $j \ne i$，共有 $N-1$ 条。非交叉配对划分 P 存在由相邻两步构成的块 $\{r, r+1\}$：取 $b-a$ 最小的块 $\{a, b\}$，注意严格位于其中的点必须与内部的点配对。在配对为 P 的树路径中，第 r、$r+1$ 步沿同一条边走出并返回，所以 $\pi(r+1) = \pi(r-1)$，且 $\pi(r)$ 在其他时刻均未被访问：它是叶节点，且不是 i。删去这两步后，剩下从 i 出发、长度为 $2k-2$ 的树路径，其配对是从 P 删去该块所得的划分，仍非交叉。反过来，在这样的较短树路径的第 $r-1$ 步后插入一次到新叶节点的往返，便可延长路径；叶节点可以是尚未使用的 $N-k$ 个顶点中的任一个。因此数量为 $(N-1)\cdots(N-k+1)(N-k)$。 □

命题 2.16. 令 C_k 为 $2k$ 个点的非交叉配对划分数，则

$$\frac{1}{N}\mathbb{E}\operatorname{tr} M^{2k} = C_k\left(1-\frac{1}{N}\right)\left(1-\frac{2}{N}\right)\cdots\left(1-\frac{k}{N}\right) + O\left(\frac{1}{N}\right) \longrightarrow C_k.$$

证明. 由引理 2.15，$T_{k,N} = C_k(N-1)\cdots(N-k)$。乘以 N^{-k} 并应用命题 2.14。 □

命题 2.17 (Catalan)**.** 令 C_k 为 $2k$ 个点的非交叉配对划分数，$C_0 = 1$。则 $C_k = \sum_{j=0}^{k-1} C_j C_{k-1-j}$，故 $C_1, \dots, C_5 = 1, 2, 5, 14, 42$。生成函数 $C(w) = \sum_k C_k w^k$ 满足

$$C(w) = 1 + wC(w)^2, \tag{6}$$

因此 $C(w) = (1 - \sqrt{1-4w})/(2w)$，$C_k = \frac{1}{k+1}\binom{2k}{k}$。

证明. 设含点 1 的块为 $\{1, b\}$。连接严格位于 1 与 b 之间的点和 b 之后的点的块会与 $\{1, b\}$ 交叉，故内部的点彼此配对，外部的点也彼此配对。因此对某个 j 有 $b = 2j+2$；内部可取 C_j 种划分之一，外部可取 C_{k-1-j} 种之一，对 j 求和得到递推式。乘以 w^k 并对 $k \ge 1$ 求和，将卷积变为乘积，得 $C - 1 = wC^2$。两个根中只有 $(1 - \sqrt{1-4w})/(2w)$ 在 $w = 0$ 有限；$\sqrt{1-4w}$ 的二项级数给出闭式。 □

2.7 涨落小

命题 2.18. 对每个 m，$\operatorname{Var}(N^{-1}\operatorname{tr} M^m) = O(1/N)$。

证明. 由式 (5)，$\operatorname{Var}(\operatorname{tr} M^m) = \sum_{\pi,\pi'} \operatorname{Cov}(W(\pi), W(\pi'))$，求和遍及长度均为 m 的闭合路径对。若 π, π' 没有共同经过的边，则 $W(\pi), W(\pi')$ 是两组不交矩阵元素的函数，故独立，协方差为零。若某条边被两条路径合计经过奇数次，则由引理 2.8 的论证，$\mathbb{E}[W(\pi)W(\pi')] = 0$，且 $\mathbb{E}W(\pi)$、$\mathbb{E}W(\pi')$ 中有一个为零。

因此存留下来的路径对有共同边，使两条路径之并连通；且每条边合计至少经过两次，使这个并集至多有 m 条边。由引理 2.13 的论证，它至多有 $m+1$ 个顶点。此类路径对至多有 cN^{m+1} 对，由引理 2.8 每个协方差至多为 $c'N^{-m}$，因此 $\operatorname{Var}(\operatorname{tr} M^m) = O(N)$。 □

由于 $N^{-1}\mathbb{E}\operatorname{tr} M^{2k} \to C_k > 0$，这给出 $\operatorname{Var}/(\mathbb{E})^2 \to 0$，即想法 3。该界不尖锐——实际上 $\operatorname{Var}(\operatorname{tr} M^m) = O(1)$——但它已足以满足想法 3 的需要。

定理 2.1 的证明. 由引理 2.2 和命题 2.16、2.17，$N^{-1}\sum_i \lambda_i^m$ 的均值在 $m = 2k$ 时趋于 C_k，而在 m 为奇数时为 0。由习题 2.21，这些是 ρ_{sc} 的矩。由命题 2.18 和 Chebyshev 不等式，$N^{-1}\sum_i \lambda_i^m$ 与其均值相差 $o(1)$ 的概率趋于 1。 □

注 2.19 (使用了什么)**.** 高斯性只通过引理 2.8 进入。命题 2.14 的证明只用到经过一次的边给出 0、矩有界，且树路径对矩阵元素除了方差外一无所见。同样证明对任何具有独立中心元素、非对角方差为 $1/N$ 且满足 $\mathbb{E}|M_{ij}|^p \le c_p N^{-p/2}$ 的对称矩阵都成立。主阶只留下矩阵元素的二阶矩，这就是半圆律的普适性来源。

习题 2.20 (A 类)**.** 画出 6 个点的全部 15 个配对划分，标记交叉，并检验恰有 5 个非交叉。对这五个划分各画一条具有该配对的树路径，并检验它有 4 个顶点。

习题 2.21 (B 类)**.** 证明 ρ_{sc} 是概率密度，且其奇数阶矩为零。然后直接积分检验

$$\int_{-2}^{2} x^2 \rho_{\mathrm{sc}}(x)\,dx = 1, \qquad \int_{-2}^{2} x^4 \rho_{\mathrm{sc}}(x)\,dx = 2,$$

即 C_1 和 C_2。作代换 $x = 2\sin\theta$。一般陈述 $\int x^{2k}\rho_{\mathrm{sc}} = C_k$ 成立，也是定理 2.1 所需要的；此处只检查前两种情形。

第 6 讲指定作业，第 7 讲开始时交： 习题 2.6、2.20、2.21，共三题。请用纸笔而非计算机做习题 2.20——画图才是重点。

3 Stieltjes 变换

问题： 计数证明产生了一列数，然后辨认出它们。密度 $\frac{1}{2\pi}\sqrt{4-x^2}$ 从何而来？
来自一个单复变量函数。M 的 Stieltjes 变换编码整个谱，围道积分从中读出特征值的数目，而密度是其极限在实轴上的虚部。本讲建立这一框架；下一讲求出极限。

计数证明留下四件事未完成。

(i) 它从未产生一个密度，只产生了一列我们辨认出来的数；对模型作扰动后便无从辨认。

(ii) 它要求所有矩有限。

(iii) 它不提供局部信息——关于单个特征值、间隙或边缘均无信息。

(iv) 它无法应对形变：方差不等或有一个秩一尖峰时，组合方法无法适应。

将多项式 x^k 换为另一族检验函数，上述四点都可修复。

3.1 矩阵的 Stieltjes 变换

定义 3.1 (预解式与 Stieltjes 变换)**.** 设 M 为对称 $N \times N$ 矩阵，特征值为 $\lambda_1, \dots, \lambda_N$。对不是特征值的 $z \in \mathbb{C}$，预解式是矩阵 $(M - zI)^{-1}$，M 的 Stieltjes 变换为

$$m_N(z) = \frac{1}{N} \operatorname{tr}(M - zI)^{-1} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{\lambda_i - z}.$$

第二个等式再次来自迹引理：对角化 $M = O\Lambda O^\top$，得 $(M - zI)^{-1} = O(\Lambda - zI)^{-1} O^\top$，其特征值为 $1/(\lambda_i - z)$。

两个事实将经常使用。第一，实轴外的 z 对应的预解式存在，因为 M 对称，故其特征值为实数，并且

$$\|(M - zI)^{-1}\| = \max_i \frac{1}{|\lambda_i - z|} \le \frac{1}{|\operatorname{Im} z|}, \qquad \text{因此} |m_N(z)| \le \frac{1}{|\operatorname{Im} z|}. \tag{7}$$

第二，m_N 是 z 的有理函数，故在复平面去掉谱之后解析。第三，当 $\operatorname{Im} z > 0$ 时，每一项 $\operatorname{Im}(\lambda_i - z)^{-1} = \operatorname{Im} z / |\lambda_i - z|^2$ 都为正，所以 $\operatorname{Im} m_N(z) > 0$。

当 M 随机时，m_N 也随机：它是手中矩阵的变换。其均值 $\mathbb{E} m_N(z)$ 是 z 的确定性函数，也有正虚部，且模至多为 $1/|\operatorname{Im} z|$；期望将始终明确写出，所以 m_N 始终只表示随机量。我们将证明两点。对实轴外的每个固定 z，$m_N(z)$ 接近 $\mathbb{E} m_N(z)$（第 4.3 节），误差在 $\operatorname{Im} z \to 0$ 时发散——固定 N 时，随机变换在 z 接近实轴时变成梳状尖峰，而其均值保持光滑，因此这一接近性确实是固定 $\operatorname{Im} z$ 下的结论。并且 $\mathbb{E} m_N(z)$ 当 $N \to \infty$ 时收敛（第 4.4 节）。

注 3.2. 第 1–2 讲第 2.5 节的岭回归为 $(H^\top H + \lambda I)^{-1} H^\top y$，其中求逆的矩阵是 $z = -\lambda$ 处的预解式。

3.2 用 Cauchy 积分公式计数特征值

从 M 转到 m_N 没有损失：可以从中读回特征值。我们真正想回答的是一个计数问题——有多少特征值落在 (a, b) 中？——Cauchy 积分公式直接回答它。

回忆。若 f 在正向简单闭合围道 Γ 上及其内部解析，除了有限个不在 Γ 上的极点，则 $(2\pi i)^{-1} \oint_\Gamma f(z)\, dz$ 等于内部各极点的留数之和。Cauchy 积分公式对应 $f(z) = g(z)/(z - w)$，其中 g 解析，且在 w 处的留数为 $g(w)$。

命题 3.3 (特征值是极点)**.** m_N 在 M 的每个不同特征值 λ 处有单极点，其留数为 $-k/N$，其中 k 是 λ 的重数；其他地方解析。因此，对任意不含特征值的正向简单闭合围道 Γ，

$$-\frac{N}{2\pi i}\oint_{\Gamma} m_N(z)\,dz = \#\{i : \lambda_i \text{ 在}\Gamma \text{ 内}\},$$

按重数计数。

证明. 将相等特征值分组：$m_N(z) = N^{-1}\sum_i (\lambda_i - z)^{-1} = N^{-1}\sum_\lambda [-k_\lambda/(z-\lambda)]$，是留数为 $-k_\lambda/N$ 的有限个单极点之和。应用留数定理并乘以 N。 □

因此谱与变换携带相同信息：特征值是极点，重数是留数，围绕一个区域积分 m_N 就能计数其中的特征值。命题 3.3 允许任意围道；选取适合问题的围道并令其收缩到实轴，便得到所需的 Stieltjes 变换反演公式：一个特征值计数公式。

定理 3.4 (作为计数的反演公式)**.** 设 M 对称，特征值为 $\lambda_1, \dots, \lambda_N$；$a < b$ 为不是 M 的特征值的实数，$\varepsilon > 0$。则

$$\begin{aligned}\#\{i : \lambda_i \in (a,b)\} = \frac{N}{\pi}\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx \\ + \frac{1}{\pi}\sum_{i=1}^{N}\left(\arctan\frac{\varepsilon}{\lambda_i - a} - \arctan\frac{\varepsilon}{\lambda_i - b}\right).\end{aligned}$$

因此，记 $d_i = \min(|\lambda_i - a|, |\lambda_i - b|)$ 为 λ_i 到端点的距离，则

$$\left|\#\{i : \lambda_i \in (a,b)\} - \frac{N}{\pi}\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx\right| \le \sum_{i=1}^{N}\min\left(1, \frac{2\varepsilon}{\pi d_i}\right).$$

证明. 令 Γ_ε 为矩形 $[a,b]\times[-\varepsilon,\varepsilon]$ 的正向边界。上面没有特征值：特征值为实数，而 Γ_ε 上仅有的实点是 a, b。内部特征值恰好是 (a,b) 中的那些，故命题 3.3 给出

$$\#\{i : \lambda_i \in (a,b)\} = -\frac{N}{2\pi i}\oint_{\Gamma_\varepsilon} m_N(z)\,dz.$$

我们精确计算四条边。由于各 λ_i 为实数，

$$\overline{m_N(z)} = \frac{1}{N}\sum_i \overline{\frac{1}{\lambda_i - z}} = \frac{1}{N}\sum_i \frac{1}{\lambda_i - \overline{z}} = m_N(\overline{z}).$$

故在高度 $-\varepsilon$ 从左向右经过的下边贡献 $\int_a^b \overline{m_N(x+i\varepsilon)}\,dx$；在高度 $+\varepsilon$ 从右向左经过的上边贡献 $-\int_a^b m_N(x+i\varepsilon)\,dx$。两者之和为

$$\int_a^b \left(\overline{m_N(x+i\varepsilon)} - m_N(x+i\varepsilon)\right)dx = -2i\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx,$$

乘以 $-N/(2\pi i)$ 后成为 $(N/\pi)\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx$。围道的水平边给出了反演公式。

左边取 $z = a + iy$，y 从 ε 降到 $-\varepsilon$，$dz = i\,dy$，故其贡献为 $-i\int_{-\varepsilon}^{\varepsilon} m_N(a+iy)\,dy$。对 m_N 的单项令 $u = \lambda_i - a \neq 0$；则 $(u - iy)^{-1} = (u+iy)/(u^2+y^2)$，其中 iy 部分关于 y 为奇函数，积分为零，且

$$\int_{-\varepsilon}^{\varepsilon}\frac{u\,dy}{u^2+y^2} = 2\arctan\frac{\varepsilon}{u}.$$

所以左边和从下向上经过的右边分别贡献

$$-\frac{2i}{N}\sum_i \arctan\frac{\varepsilon}{\lambda_i-a},\qquad +\frac{2i}{N}\sum_i \arctan\frac{\varepsilon}{\lambda_i-b}.$$

乘以 $-N/(2\pi i)$ 即得命题中的两个反正切求和。

对于界，$|\arctan t|\le \min(\pi/2,|t|)$，所以修正项的第 i 项绝对值至多为

$$\frac{1}{\pi}\left[\min\left(\frac{\pi}{2},\frac{\varepsilon}{|\lambda_i-a|}\right)+\min\left(\frac{\pi}{2},\frac{\varepsilon}{|\lambda_i-b|}\right)\right]\le \min\left(1,\frac{2\varepsilon}{\pi d_i}\right).$$

□

修正项是对特征值求和：远离端点者贡献 $O(\varepsilon/d_i)$，距端点在 ε 以内者贡献 $O(1)$。除以 N 并在阈值 η 处分割求和：

推论 3.5 (比例)**.** 对任意 $\varepsilon>0$、$\eta>0$，

$$\left|\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}-\frac{1}{\pi}\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx\right|\le \frac{2\varepsilon}{\pi\eta}+\frac{\#\{i:d_i\le\eta\}}{N}.$$

证明. 定理 3.4 的和中，$d_i>\eta$ 的每项至多为 $2\varepsilon/(\pi\eta)$，此类项至多 N 项；$d_i\le\eta$ 的每项至多为 1。 □

第二项是需要关注的部分：它涉及特征值在哪里，而这正是我们试图求出的信息。解决办法是变换控制其自身的局部计数。

引理 3.6 (变换约束局部计数)**.** 对任意实数 a 和 $\eta>0$，

$$\frac{1}{N}\#\{i:|\lambda_i-a|\le\eta\}\le 2\eta\operatorname{Im} m_N(a+i\eta).$$

证明. $\operatorname{Im} m_N(a+i\eta)=N^{-1}\sum_i \eta/[(\lambda_i-a)^2+\eta^2]$；每项均为正，而满足 $|\lambda_i-a|\le\eta$ 的每项至少为 $(2\eta N)^{-1}$。 □

因此，距离 a 在 η 以内的特征值比例至多为 $2\eta\operatorname{Im} m_N(a+i\eta)$，而 m_N 正是本讲余下部分计算的量。无需假设密度；密度将从极限读出。

命题 3.7 (从变换到比例)**.** 假设上半平面上存在函数 m，满足 $\operatorname{Im} m\le K$，且对每个 $\varepsilon>0$、每个 $L<\infty$，当 $N\to\infty$ 时，

$$\sup_{|x|\le L}|\mathbb{E}m_N(x+i\varepsilon)-m(x+i\varepsilon)|\longrightarrow 0,$$

$$\sup_{|x|\le L}\mathbb{E}|m_N(x+i\varepsilon)-\mathbb{E}m_N(x+i\varepsilon)|\longrightarrow 0.$$

则对任意实数 $a<b$，极限

$$\ell(a,b)=\lim_{\varepsilon\downarrow 0}\frac{1}{\pi}\int_a^b \operatorname{Im} m(x+i\varepsilon)\,dx$$

存在，且

$$\mathbb{E}\left|\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}-\ell(a,b)\right|\longrightarrow 0.$$

证明. 固定 $\varepsilon,\eta>0$，记 $p_N=N^{-1}\#\{i:\lambda_i\in(a,b)\}$。推论 3.5 结合对 a,b 应用引理 3.6，对 M 的每个实现给出

$$\left|p_N-\frac{1}{\pi}\int_a^b \operatorname{Im} m_N(x+i\varepsilon)\,dx\right|\le\frac{2\varepsilon}{\pi\eta}+2\eta\big(\operatorname{Im} m_N(a+i\eta)+\operatorname{Im} m_N(b+i\eta)\big).$$

在积分内将 m_N 替换为 m。由于 $|\operatorname{Im} m_N-\operatorname{Im} m|\le|m_N-\mathbb{E}m_N|+|\mathbb{E}m_N-m|$，记

$$\begin{aligned}r_N(\varepsilon)=&\sup_{x\in[a,b]}\mathbb{E}|m_N(x+i\varepsilon)-\mathbb{E}m_N(x+i\varepsilon)|\\&+\sup_{x\in[a,b]}|\mathbb{E}m_N(x+i\varepsilon)-m(x+i\varepsilon)|,\end{aligned}$$

得到

$$\mathbb{E}\left|\frac{1}{\pi}\int_a^b(\operatorname{Im} m_N-\operatorname{Im} m)(x+i\varepsilon)\,dx\right|\le\frac{b-a}{\pi}r_N(\varepsilon).$$

对第一个显示公式取期望：

$$\begin{aligned}\mathbb{E}\left|p_N-\frac{1}{\pi}\int_a^b\operatorname{Im} m(x+i\varepsilon)\,dx\right|\le&\frac{2\varepsilon}{\pi\eta}+2\eta\big(\operatorname{Im}\mathbb{E}m_N(a+i\eta)+\operatorname{Im}\mathbb{E}m_N(b+i\eta)\big)\\&+\frac{b-a}{\pi}r_N(\varepsilon).\end{aligned}$$

令 $N\to\infty$。由假设 $r_N(\varepsilon)\to0$，且 $\operatorname{Im}\mathbb{E}m_N(a+i\eta)\to\operatorname{Im} m(a+i\eta)\le K$，$b$ 处同理。于是取 $\eta=\sqrt{\varepsilon}$，

$$\limsup_{N\to\infty}\mathbb{E}\left|p_N-\frac{1}{\pi}\int_a^b\operatorname{Im} m(x+i\varepsilon)\,dx\right|\le\frac{2\varepsilon}{\pi\eta}+4K\eta=\left(\frac{2}{\pi}+4K\right)\sqrt{\varepsilon}.$$

对 ε,ε' 分别应用此式，通过同一个 p_N 使用三角不等式，表明 $\pi^{-1}\int_a^b\operatorname{Im} m(x+i\varepsilon)\,dx$ 与 ε' 对应的积分之差至多为 $(2/\pi+4K)(\sqrt{\varepsilon}+\sqrt{\varepsilon'})$，故极限 $\ell(a,b)$ 存在。于是对每个 $\varepsilon>0$，

$$\limsup_{N\to\infty}\mathbb{E}|p_N-\ell|\le\left(\frac{2}{\pi}+4K\right)\sqrt{\varepsilon}+\left|\frac{1}{\pi}\int_a^b\operatorname{Im} m(x+i\varepsilon)\,dx-\ell\right|,$$

右侧当 $\varepsilon\downarrow0$ 时趋于 0。 □

注 3.8 (极限次序)**.** 证明先固定 ε 取 $N\to\infty$，之后才令 $\varepsilon\downarrow0$。这一顺序是被迫的：推论 3.5 的误差一致地对 N 小，但只有在 $\varepsilon\ll\eta$ 且 η 小时才如此，二者均与 N 无关。反过来的次序问的是另一问题。固定 N 时，定理 3.4 称计数误差为 $\sum_i\min(1,2\varepsilon/(\pi d_i))$；若 N 个特征值间距为 $1/N$ 的量级，它就是 $\varepsilon N\log N$ 的量级，故要精确计数，ε 必须小于间距。这是局部区域；习题 3.12 显示这里的 $\operatorname{Im} m_N$ 呈什么样子：梳状尖峰，每个特征值一个。习题 3.11 画出两个区域，交叉发生在 $\varepsilon\sim1/N$。

定理 3.4 是密度产生的唯一位置，且现在已证明而非引用。它也精确告诉我们要计算什么。第 8 讲计算

$$\rho(x)=\lim_{\varepsilon\downarrow0}\lim_{N\to\infty}\frac{1}{\pi}\operatorname{Im}\mathbb{E}m_N(x+i\varepsilon).\tag{8}$$

命题 3.7 使得该答案有资格被称为密度：一旦已知 $\mathbb{E}m_N\to m$，任意区间中的特征值比例收敛到式 (8) 右侧在该区间上的积分，不需进一步假设。关于式 (8) 有两点说明。期望无妨：固定 ε 时，m_N 在 L^1 中与其均值相差 $O(1/N)$，这是第 4.3 节的结论，故框中的式子也可写成 m_N，并在 L^1 中取内层极限。极限次序不是技术细节，而是内容：固定 N 先令 $\varepsilon\downarrow0$，返回的是 N 个逐一呈现的特征值，根本没有密度。

3.3 无穷远处的变换：迹的生成函数

图景的另一端是 $z \to \infty$。当 $|z| > \max_i |\lambda_i|$ 时，Neumann 级数

$$(M - zI)^{-1} = -\sum_{k\geq 0} \frac{M^k}{z^{k+1}}$$

收敛，取迹得

$$m_N(z) = -\sum_{k\geq 0} \frac{1}{z^{k+1}} \frac{1}{N} \operatorname{tr} M^k, \qquad \text{即} \quad -zm_N(z) = \sum_{k\geq 0} \left(\frac{1}{N}\operatorname{tr} M^k\right) \frac{1}{z^k}. \tag{9}$$

因此无穷远附近的归一化变换是以 $1/z$ 为变量的归一化迹矩的生成函数：它逐个系数携带第 2 节计算的全部信息。$k = 0$ 项给出 $m_N(z) = -1/z + O(|z|^{-2})$，这与第 4.4 节引理 4.9(b) 中求出的极限的行为一致，也是注 4.17 的起点。

由第 2.4 节，$\operatorname{tr} M^k$ 是长度 k 的闭合路径之和，故：

注 3.9 (预解式是什么)**.** $-zm_N(z)$ 是 M 中闭合路径的生成函数，按长度计数并除以 N，其中 $1/z$ 标记一步。定理 2.1 的两种证明是读取同一函数的两种方式：第 2 节通过路径计数逐个计算其在 $z = \infty$ 处的 Taylor 系数；第 4.2 节则不计算任何系数，直接求整个函数的方程。对半圆律，系数是 Catalan 数，$m(z) = -\sum_{k\geq 0} C_k z^{-(2k+1)}$，奇数阶矩由对称性消失。

习题 3.10 (A 类)**.** 对两种情形闭式计算 $m_N(z) = N^{-1}\sum_{i=1}^{N}(\lambda_i - z)^{-1}$：(a) $M = 0$；(b) M 有 $N/2$ 个特征值等于 -1，另有 $N/2$ 个等于 $+1$。每种情形均验证界 (7)，并检验当 $z \to \infty$ 时 $m_N(z) = -1/z + O(|z|^{-2})$。

习题 3.11 (A 类)**.** 对 $N = 2000$ 的 GOE 矩阵作数值计算，画出 $\varepsilon = 1, 0.1, 0.001$ 时的曲线：以 $\lambda \in [-3, 3]$ 为横坐标，以 $\pi^{-1}\operatorname{Im} m_N(\lambda + i\varepsilon)$ 为纵坐标，并叠加 ρ_{sc}。$\varepsilon = 1$ 时曲线是平滑化的半圆；$\varepsilon = 0.001$ 时它是在各个特征值处的一片尖峰。两者之间某处是整体规律，交叉发生在 $\varepsilon \sim 1/N$。

习题 3.12 (B 类)**.** 变换中每个特征值及其重数都可见。设 M 对称，特征值为 $\lambda_1, \ldots, \lambda_N$。对 $\lambda \in \mathbb{R}$、$\varepsilon > 0$，证明

$$\operatorname{Im} m_N(\lambda + i\varepsilon) = \frac{1}{N}\sum_{i=1}^{N} \frac{\varepsilon}{(\lambda_i - \lambda)^2 + \varepsilon^2} > 0,$$

故上半平面上 $\operatorname{Im} m_N > 0$，并推得对每个 $\lambda \in \mathbb{R}$，

$$\lim_{\varepsilon \downarrow 0} \varepsilon \operatorname{Im} m_N(\lambda + i\varepsilon) = \frac{1}{N}\#\{i : \lambda_i = \lambda\}.$$

每个特征值对 $\operatorname{Im} m_N$ 贡献一个高度 $1/(N\varepsilon)$、宽度 ε 的凸峰。以此解释习题 3.11 的图像：为什么这些峰必须重叠，$\pi^{-1}\operatorname{Im} m_N$ 才能看起来像一条曲线？为什么这强制 $\varepsilon \gg 1/N$？

第 7 讲指定作业，第 8 讲开始时交：习题 3.10、3.11、3.12，共三题，其中一题是数值题。本讲任何内容都不需要第 8 讲。

4 通过 Stieltjes 变换证明半圆律

问题： 不计算任何一个矩，如何求 $\mathbb{E}m_N(z)$ 的极限?
从固定点方程出发。删去 M 的一行和一列，可以用较小矩阵的预解式表达原预解式的一个对角元；取平均使之成为变换必须满足的方程，只差一个被集中性消去的误差。方程是稳定的，故 $\mathbb{E}m_N$ 收敛到其解，而引理 4.11 从该解读出半圆律。

本节始终令 M 为高斯 Wigner 矩阵，z 固定且 $\operatorname{Im} z = \varepsilon > 0$；$m_N, \mathbb{E}m_N$ 如定义 3.1。本讲分四部分：一段线性代数（第 4.1 节）、带显式误差界的方程推导（第 4.2 节）、该推导需要的唯一概率估计（第 4.3 节），以及方程的求解和它证明的定理（第 4.4 节）。到最后，命题 3.7 的全部要求都将满足。

4.1 Schur 补

本讲的核心机制是：预解式的一个对角元可用较小矩阵的预解式表示。这是线性代数，对任意分块矩阵均成立。

引理 4.1 (Schur 补)**.** 设方阵 $A = \begin{pmatrix} P & Q \\ R & S \end{pmatrix}$ 分块，S 为可逆方阵，令 $T = P - QS^{-1}R$，即 S 在 A 中的 Schur 补。则 A 可逆当且仅当 T 可逆；此时

$$A^{-1} = \begin{pmatrix} T^{-1} & -T^{-1}QS^{-1} \\ -S^{-1}RT^{-1} & S^{-1} + S^{-1}RT^{-1}QS^{-1} \end{pmatrix}.$$

特别地，A^{-1} 的左上角块为 T^{-1}。

证明. 通过分块行变换消去 Q：

$$\begin{pmatrix} I & -QS^{-1} \\ 0 & I \end{pmatrix} \begin{pmatrix} P & Q \\ R & S \end{pmatrix} = \begin{pmatrix} T & 0 \\ R & S \end{pmatrix} =: L.$$

左侧因子 U 可逆，$U^{-1} = \begin{pmatrix} I & QS^{-1} \\ 0 & I \end{pmatrix}$，故 A 可逆当且仅当 L 可逆；而 L 是对角块为 T, S 的分块下三角矩阵，所以它可逆当且仅当 T 可逆。此时 $A^{-1} = L^{-1}U$，且

$$L^{-1} = \begin{pmatrix} T^{-1} & 0 \\ -S^{-1}RT^{-1} & S^{-1} \end{pmatrix},$$

$$L^{-1}U = \begin{pmatrix} T^{-1} & -T^{-1}QS^{-1} \\ -S^{-1}RT^{-1} & S^{-1} + S^{-1}RT^{-1}QS^{-1} \end{pmatrix},$$

即所给的逆矩阵。 □

取 P 为位置 $(1,1)$ 的单个元素，T 就是标量，引理成为：

推论 4.2. 设 $A = \begin{pmatrix} \alpha & b^\top \\ b & D \end{pmatrix}$，其中 α 是标量，b 是列向量，D 可逆。若 $\alpha - b^\top D^{-1} b \neq 0$，则 A 可逆，且

$$g := (A^{-1})_{11} = \frac{1}{\alpha - b^\top D^{-1} b}, \qquad \operatorname{tr} A^{-1} = \operatorname{tr} D^{-1} + g(1 + b^\top D^{-2} b).$$

证明. 第一个公式是左上角块。右下角块为 $D^{-1}+gD^{-1}bb^{\top}D^{-1}$，其迹为 $\operatorname{tr}D^{-1}+gb^{\top}D^{-2}b$；再加上角上的元素 g。 □

将它应用于 $A=M-zI$。记 $M^{(1)}$ 为删去 M 第一行和第一列所得矩阵，第一列其余部分记为

$$a=(M_{21},\dots,M_{N1})^{\top}\in\mathbb{R}^{N-1}.$$

则 $\alpha=M_{11}-z$、$b=a$、$D=M^{(1)}-zI$，且

$$\big((M-zI)^{-1}\big)_{11}=\frac{1}{M_{11}-z-a^{\top}(M^{(1)}-zI)^{-1}a}. \tag{10}$$

注 4.3. 这与第 1–2 讲第 2.4 节的恒等式相同，那里 Schur 补给出了高斯向量的条件方差。那里较小的矩阵是协方差；这里它是预解式。

4.2 自洽方程

固定 $\operatorname{Im}z>0$，记 $R=(M^{(1)}-zI)^{-1}$、$\varepsilon=\operatorname{Im}z$。论证分四步，只有第二步是概率性的，最后得到定量陈述。

第 0 步：一个元素足够。对置换矩阵 Q，$QMQ^{\top}$ 与 M 同分布（注 1.8），而 $(Q(M-zI)^{-1}Q^{\top})_{11}$ 是预解式的另一个对角元，故全部 N 个对角元同分布，且

$$\mathbb{E}m_N(z)=\mathbb{E}[((M-zI)^{-1})_{11}]. \tag{11}$$

第 1 步：Schur 补。由式 (10)，该元素为 $(M_{11}-z-a^{\top}Ra)^{-1}$。首先注意分母绝不会很小：$a^{\top}Ra=\sum_k\langle a,u_k\rangle^2/(\mu_k-z)$，其中 μ_k,u_k 为 $M^{(1)}$ 的特征值和特征向量，故 $\operatorname{Im}(a^{\top}Ra)>0$，因此

$$|M_{11}-z-a^{\top}Ra|\geq\operatorname{Im}z. \tag{12}$$

下文均是在该分母上作扰动，式 (12) 将它变为对该元素的扰动：若 $|w|,|w'|\geq\operatorname{Im}z$，则 $|w^{-1}-w'^{-1}|\leq|w-w'|/(\operatorname{Im}z)^2$。

第 2 步：二次型集中。向量 a 由 $M_{21},\dots,M_{N1}$ 构成，$M^{(1)}$ 由 $i,j\geq2$ 的 M_{ij} 构成。它们是 M 中不交的元素集合，故 a 与 $M^{(1)}$ 独立，进而与 R 独立。并且 $a\sim\mathcal{N}(0,N^{-1}I_{N-1})$。

引理 4.4. 设 R 是可能为复数的对称 $(N-1)\times(N-1)$ 矩阵，$a\sim\mathcal{N}(0,N^{-1}I_{N-1})$。则

$$\mathbb{E}[a^{\top}Ra]=\frac{1}{N}\operatorname{tr}R,\qquad\qquad\mathbb{E}\left|a^{\top}Ra-\frac{1}{N}\operatorname{tr}R\right|^2=\frac{2}{N^2}\sum_{r,s}|R_{rs}|^2.$$

特别地，若 $R=(M^{(1)}-zI)^{-1}$，则右侧至多为 $2/[N(\operatorname{Im}z)^2]$。

证明. $\mathbb{E}[a_ra_s]=\delta_{rs}/N$ 给出均值。对二阶矩，$a^{\top}Ra-N^{-1}\operatorname{tr}R=\sum_{r,s}R_{rs}(a_ra_s-\delta_{rs}/N)$，故

$$\mathbb{E}\left|a^{\top}Ra-\frac{1}{N}\operatorname{tr}R\right|^2=\sum_{r,s,t,u}R_{rs}\overline{R_{tu}}\left(\mathbb{E}[a_ra_sa_ta_u]-\frac{\delta_{rs}\delta_{tu}}{N^2}\right).$$

由定理 1.2，$\mathbb{E}[a_r a_s a_t a_u] = N^{-2}(\delta_{rs}\delta_{tu} + \delta_{rt}\delta_{su} + \delta_{ru}\delta_{st})$，所以括号为 $N^{-2}(\delta_{rt}\delta_{su} + \delta_{ru}\delta_{st})$，求和得到

$$\frac{1}{N^2}\left(\sum_{r,s} R_{rs}\overline{R_{rs}} + \sum_{r,s} R_{rs}\overline{R_{sr}}\right) = \frac{2}{N^2}\sum_{r,s}|R_{rs}|^2,$$

这里使用 $R_{sr} = R_{rs}$。最后，$\sum_{r,s}|R_{rs}|^2 = \operatorname{tr}(R\overline{R})$ 是 R 的奇异值平方之和；由界 (7)，每个奇异值至多为 $\|R\| \le 1/\operatorname{Im} z$，共有 $N-1$ 个。 □

因此 $a^\top R a = N^{-1}\operatorname{tr} R + \epsilon_N$，其中 $\mathbb{E}|\epsilon_N|^2 \le 2/[N(\operatorname{Im} z)^2]$：二次型在 L^2 中以 $O(N^{-1/2})$ 精度等于自己的平均值。这是唯一引入概率的地方。

第 3 步：较小的迹与原迹相同。第 1 步出现的是低一维矩阵的预解式迹 $N^{-1}\operatorname{tr} R$；我们需要的是 $m_N = N^{-1}\operatorname{tr}(M - zI)^{-1}$。二者相差很小，Schur 补精确给出差异。由推论 4.2，记 $g = ((M - zI)^{-1})_{11}$，则

$$\operatorname{tr}(M - zI)^{-1} - \operatorname{tr} R = g(1 + a^\top R^2 a).$$

两个事实约束右侧。第一，第 1 步分母的虚部为 $-\varepsilon - \operatorname{Im}(a^\top R a)$，故 $|g| \le [\varepsilon + \operatorname{Im}(a^\top R a)]^{-1}$。第二，

$$R - \overline{R} = R[(M^{(1)} - \overline{z}I) - (M^{(1)} - zI)]\overline{R} = 2i\varepsilon R\overline{R},$$

因此 $\operatorname{Im}(a^\top R a) = \varepsilon a^\top R\overline{R}a = \varepsilon\|Ra\|^2$，因为 R 对称且 a 为实向量；而 $a^\top R^2 a = (Ra)^\top(Ra)$ 的模至多为 $\|Ra\|^2$。记 $t = \operatorname{Im}(a^\top R a) \ge 0$，则

$$|g|\,|1 + a^\top R^2 a| \le \frac{1 + t/\varepsilon}{\varepsilon + t} = \frac{1}{\varepsilon},$$

即

$$\left|\operatorname{tr}(M - zI)^{-1} - \operatorname{tr}(M^{(1)} - zI)^{-1}\right| \le \frac{1}{\varepsilon}. \tag{13}$$

删除一行一列使预解式的迹移动至多一个项的量。除以 N，得 $|m_N - N^{-1}\operatorname{tr} R| \le 1/(N\varepsilon)$。

第 4 步：合并。将第 1 步分母中不是 $-z - m_N$ 的部分合并为余项：

$$M_{11} - z - a^\top R a = -z - m_N + \Delta,$$
$$\Delta = M_{11} - \left(a^\top R a - \frac{1}{N}\operatorname{tr} R\right) + \left(m_N - \frac{1}{N}\operatorname{tr} R\right).$$

由 $\mathbb{E}M_{11}^2 = 2/N$、引理 4.4 和式 (13)，对前两项使用 $\mathbb{E}|X| \le (\mathbb{E}|X|^2)^{1/2}$，得

$$\mathbb{E}|\Delta| \le \sqrt{\frac{2}{N}} + \frac{\sqrt{2}}{\varepsilon\sqrt{N}} + \frac{1}{N\varepsilon}.$$

$-z - m_N + \Delta$（由式 (12)）与 $-z - m_N$（因 $\operatorname{Im} m_N > 0$）的模均至少为 ε，因此由式 (12) 后的说明，

$$\left|((M - zI)^{-1})_{11} - \frac{1}{-z - m_N}\right| \le \frac{|\Delta|}{\varepsilon^2}.$$

同一说明可将 m_N 替换为其均值，其均值也有 $\operatorname{Im}\mathbb{E}m_N > 0$：两个倒数的差至多为 $|m_N - \mathbb{E}m_N|/\varepsilon^2$。现在取期望，左侧使用式 (11)：

$$\left|\mathbb{E}m_N(z) - \frac{1}{-z - \mathbb{E}m_N(z)}\right| \le \frac{\mathbb{E}|\Delta| + \mathbb{E}|m_N - \mathbb{E}m_N|}{\varepsilon^2} =: \delta_N(\varepsilon). \tag{14}$$

尚有一项未控制：$\mathbb{E}|m_N - \mathbb{E}m_N|$。随机变换必须接近自身均值。这是第 4.3 节的内容，其结论为 $\mathbb{E}|m_N - \mathbb{E}m_N| \le 3/(N\varepsilon^2)$。合在一起，对 $0 < \varepsilon \le 1$ 和每个满足 $\operatorname{Im} z = \varepsilon$ 的 z，

$$\delta_N(\varepsilon) = \frac{1}{\varepsilon^2}\left[\sqrt{\frac{2}{N}} + \frac{\sqrt{2}}{\varepsilon\sqrt{N}} + \frac{1}{N\varepsilon} + \frac{3}{N\varepsilon^2}\right] \le \frac{7}{\varepsilon^4\sqrt{N}}, \tag{15}$$

它仅通过 ε 依赖于 z。因此 $\mathbb{E}m_N$ 满足

$$m(z) = \frac{1}{-z - m(z)}, \qquad \text{即} m^2 + zm + 1 = 0, \tag{16}$$

误差为 $N^{-1/2}$ 量级。第 4.4 节说明方程稳定，故 $\mathbb{E}m_N$ 收敛到其解。

式 (16) 是答案的固定点方程，推导时并不知道答案。矩方法则需要预先知道要辨认什么。

4.3 迹的集中

第 4 步尚欠缺的估计是 m_N 接近其均值 $\mathbb{E}m_N$。这是最后缺失的一块，值得认真推导，因为结果的大小令人意外。

问题的形状如下。$Nm_N(z) = \sum_i (\lambda_i - z)^{-1}$ 是 N 项之和，每项的模至多为 $1/\operatorname{Im} z$。若各 λ_i 独立，这样的和会有 N 阶方差，而 m_N 的涨落尺度为 $N^{-1/2}$。我们将发现整个和的方差为 $O(1)$：特征值足够刚性，使 N 个特征值合在一起的涨落不超过单个特征值的涨落量级。

引理 4.5 (高斯 Poincaré 不等式)**.** 设 $X_1, \dots, X_n$ 独立，$X_i \sim \mathcal{N}(0, \sigma_i^2)$，且 $f : \mathbb{R}^n \to \mathbb{R}$ 连续可微、梯度有界。则

$$\operatorname{Var} f(X) \le \frac{\pi^2}{8} \sum_{i=1}^{n} \sigma_i^2 \mathbb{E}[(\partial_i f(X))^2].$$

证明. 将 $f(x)$ 换为 $f(\sigma_1 x_1, \dots, \sigma_n x_n)$，可令每个 $\sigma_i = 1$。设 Y 是 X 的独立副本，通过旋转插值：对 $\theta \in [0, \pi/2]$，令

$$X_\theta = X\sin\theta + Y\cos\theta, \qquad X'_\theta = X\cos\theta - Y\sin\theta.$$

对固定 θ，(X_θ, X'_θ) 是标准高斯向量 (X, Y) 的线性像，故联合高斯，且

$$\mathbb{E}[X_\theta X_\theta^\top] = \mathbb{E}[X'_\theta (X'_\theta)^\top] = I, \qquad \mathbb{E}[X_\theta (X'_\theta)^\top] = (\sin\theta\cos\theta - \cos\theta\sin\theta) I = 0.$$

因此 X_θ 与 X'_θ 是独立标准高斯向量。由于 $\frac{d}{d\theta} X_\theta = X'_\theta$，且 $X_{\pi/2} = X$、$X_0 = Y$，

$$f(X) - f(Y) = \int_0^{\pi/2} \langle \nabla f(X_\theta), X'_\theta \rangle \, d\theta,$$

在长度为 $\pi/2$ 的区间上应用 Cauchy–Schwarz，

$$(f(X) - f(Y))^2 \le \frac{\pi}{2} \int_0^{\pi/2} \langle \nabla f(X_\theta), X'_\theta \rangle^2 \, d\theta.$$

取期望；被积函数有界，因此 $\mathbb{E}$ 与 $d\theta$ 可交换。

译注： 原文“有界”不准确：即使 $f(x)=x$，该平方被积函数仍是无界的高斯平方。平方非负，可用 Tonelli；若 $\|\nabla f\|\le C$，又有 $\mathbb{E}|\langle\nabla f(X_\theta),X_\theta'\rangle|^2\le C^2\mathbb{E}\|X_\theta'\|^2<\infty$，在有限 θ 区间可积，足以交换。

对固定 θ，以 X_θ 为条件：由刚证明的独立性，

$$\mathbb{E}\langle\nabla f(X_\theta),X_\theta'\rangle^2=\mathbb{E}\|\nabla f(X_\theta)\|^2=\mathbb{E}\|\nabla f(X)\|^2.$$

故 $\mathbb{E}[(f(X)-f(Y))^2]\le(\pi^2/4)\mathbb{E}\|\nabla f\|^2$；又因 X,Y 是独立副本，$\operatorname{Var}f(X)=\frac12\mathbb{E}[(f(X)-f(Y))^2]$。□

常数 $\pi^2/8$ 可改进为尖锐的 1，但下文不依赖于此。注意右侧是什么、又不是什么：它不是 n 乘以一个典型的导数平方，而是求和。一个 n 个独立高斯变量的函数，若其 n 个偏导数均为 $n^{-1/2}$ 量级，则无论 n 多大，其方差均为 $O(1)$。我们的 f 正属于此类。

命题 4.6. 设 M 为高斯 Wigner 矩阵，$\operatorname{Im}z=\varepsilon>0$。则

$$\operatorname{Var}\operatorname{Re}\operatorname{tr}(M-zI)^{-1}\le\frac{\pi^2}{4\varepsilon^4},$$

虚部也有相同的界。因此

$$\mathbb{E}|m_N(z)-\mathbb{E}m_N(z)|^2\le\frac{\pi^2}{2N^2\varepsilon^4},\qquad\mathbb{E}|m_N(z)-\mathbb{E}m_N(z)|\le\frac{\pi}{\sqrt2\,N\varepsilon^2}<\frac{3}{N\varepsilon^2}.$$

证明. 独立坐标是 $i\le j$ 的元素 M_{ij}，非对角线上 $\operatorname{Var}M_{ij}=1/N$，对角线上为 $2/N$。记 $R=(M-zI)^{-1}$、$f(M)=\operatorname{tr}R$。用预解式恒等式对 $\operatorname{tr}(M+tH-zI)^{-1}$ 在 $t=0$ 处求导，得到

$$\frac{d}{dt}\operatorname{tr}(M+tH-zI)^{-1}\Big|_{t=0}=-\operatorname{tr}(RHR)=-\operatorname{tr}(HR^2).$$

当 $i<j$ 取 $H=E_{ij}+E_{ji}$，对角线取 $H=E_{ii}$，则

$$\frac{\partial f}{\partial M_{ij}}=-2(R^2)_{ij}\quad(i<j),\qquad\qquad\frac{\partial f}{\partial M_{ii}}=-(R^2)_{ii}.$$

于是 Poincaré 求和为

$$\sum_{i<j}\frac{1}{N}4|(R^2)_{ij}|^2+\sum_i\frac{2}{N}|(R^2)_{ii}|^2=\frac{2}{N}\sum_{i,j}|(R^2)_{ij}|^2.$$

现将 $M=O\Lambda O^\top$ 对角化，得 $R^2=O(\Lambda-zI)^{-2}O^\top$，其特征值为 $(\lambda_i-z)^{-2}$，而 $\sum_{i,j}|(R^2)_{ij}|^2$ 在用 O 共轭时不变。因此

$$\sum_{i,j}|(R^2)_{ij}|^2=\sum_i\frac{1}{|\lambda_i-z|^4}\le\frac{N}{(\operatorname{Im}z)^4},$$

Poincaré 求和至多为 $2/\varepsilon^4$，不再含 N；引理 4.5 将其乘以 $\pi^2/8$。由于 $|\partial_{ij}\operatorname{Re}f|\le|\partial_{ij}f|\le2/\varepsilon^2$，该引理分别适用于 $\operatorname{Re}f$ 和 $\operatorname{Im}f$；将两者相加再除以 N^2 得到第二个显示公式，最后一个不等式为 Cauchy–Schwarz。□

N 沿相反方向抵消了两次：每个导数为 $N^{-1/2}$ 量级，因为元素方差为 $1/N$，这样的导数有 N^2 个；但它们的平方和是预解式幂的迹，即 N 乘以有界数，而非 N^2 乘以有界数。关键是恒等式 $\sum_{i,j}|(R^2)_{ij}|^2=\sum_i|\lambda_i-z|^{-4}$：迹的梯度不是一般向量，而是另一个谱和。

译注： $N^{-1/2}$ 的链式缩放属于标准化独立高斯坐标或方差加权导数，而非前面使用的原始 M_{ij} 导数。例如 $M=0, z=i$ 时，对角导数 $-(R^2)_{ii}=1$，并不随 N 缩小。前面显式的方差加权求和是正确的。

注 4.7 (刚性体现于此)**.** $\operatorname{Var}\operatorname{tr}(M-zI)^{-1}=O(1)$ 表明随机矩阵的线性统计量 $\sum_i f(\lambda_i)$ 满足无需任何归一化的中心极限定理——没有 $1/\sqrt{N}$，因为 N 项之和已经是常数量级。对于独立点这不成立。这是特征值相互排斥的第一个定量迹象，第 8 讲将精确说明。

译注： 方差 $O(1)$ 只说明涨落尺度，不能据此推出高斯分布极限。例如固定的中心 Rademacher 随机变量方差恒为 1，但不是高斯。线性统计量的中心极限定理还须说明中心化、极限方差、检验函数及额外假设；本命题未证明这些信息。

注 4.8 (高斯性是便利条件而非原因)**.** 对任何元素独立的 Wigner 矩阵，即使不假设高斯性，也有一个较弱的界。令 $\mathcal{F}_k$ 由 M 的前 k 行和列生成，将 $\operatorname{tr}R-\mathbb{E}\operatorname{tr}R=\sum_{k=1}^{N}D_k$ 分解为鞅差

$$D_k=\mathbb{E}[\operatorname{tr}R\mid\mathcal{F}_k]-\mathbb{E}[\operatorname{tr}R\mid\mathcal{F}_{k-1}].$$

删去第 k 行和列所得矩阵 $M^{(k)}$ 不涉及第 k 行，所以 $\operatorname{tr}(M^{(k)}-zI)^{-1}$ 在给定 $\mathcal{F}_k$ 和给定 $\mathcal{F}_{k-1}$ 时有相同条件期望，可以在两项中减去；再由式 (13) 得 $|D_k|\le 2/\operatorname{Im}z$。鞅差正交，故 $\operatorname{Var}(\operatorname{tr}R)=O(N)$、$\operatorname{Var}(N^{-1}\operatorname{tr}R)=O(1/N)$。这已足够用于第 4 步。高斯论证将 $O(1/N)$ 改进为真实的 $O(1/N^2)$，且式 (15) 的速率需要它。

4.4 求解方程与定理

两个根。当 $\operatorname{Im}z>0$ 时，方程 $w^2+zw+1=0$ 有两个根，乘积为 1，和为 $-z$。它们都不在单位圆上：若 $|w|=1$，则另一个根为 $1/w=\overline{w}$，而 $z=-(w+\overline{w})=-2\operatorname{Re}w$ 为实数。因此恰有一个根位于单位圆盘内。称其为 $m(z)$，另一个根为 $m'(z)=1/m(z)$。这就是 m 的定义。熟悉的带平方根公式及平方根的选支将在下面得出。

引理 4.9 (好的根)**.** 令 $\operatorname{Im}z=\varepsilon>0$。

(a) $|m(z)|<1$，且 m 在上半平面连续（事实上解析）。

(b) 当 $|z|>1$ 时，$|m(z)|\le 1/(|z|-1)$ 且 $|m(z)+1/z|\le 1/[|z|(|z|-1)^2]$；特别地，$m(z)=-1/z+O(|z|^{-3})$。

(c) $\operatorname{Im}m(z)>0$，且 $\operatorname{Im}m'(z)<-\varepsilon$。

(d) $m(z)=(-z+\sqrt{z^2-4})/2$，其中 $\sqrt{z^2-4}$ 是虚部为正的平方根。（$w\notin[0,\infty)$ 有两个互为相反数的平方根，故恰有一个虚部为正；而当 $\operatorname{Im}z>0$ 时 $z^2-4\notin[0,\infty)$，因此上半平面每个 z 都由此连续地确定一个数。这不是主支：主支的割线位于 $z^2-4<0$ 处，包括整个虚轴；使用主平方根时 $(-z+\sqrt{z^2-4})/2$ 在 z 穿过虚轴时会从小根切换到大根。）此外，m 连续延拓到闭上半平面，且当 $|\lambda|\le 2$ 时 $\operatorname{Im}m(\lambda+i0)=\frac{1}{2}\sqrt{4-\lambda^2}$；当 $|\lambda|\ge 2$ 时 $\operatorname{Im}m(\lambda+i0)=0$。

证明. (a) $|m|<1$ 是定义。上半平面内判别式 z^2-4 不为零，故在任何点附近两个根均由 z 的解析函数给出；它们都不会碰到单位圆，因此圆盘内的根始终留在圆盘内，即为 m。

(b) 由 $m'=-z-m$ 和 $|m|<1$，$|m'|\geq|z|-1$，因此 $|m|=1/|m'|\leq 1/(|z|-1)$：小根很小，因为大根是 $-z$ 加一个有界误差，且两根乘积为 1。为得到更尖锐的结论，将方程写为 $m(-z-m)=1$，即 $m=1/(-z-m)$。于是

$$m+\frac{1}{z}=\frac{1}{-z-m}+\frac{1}{z}=\frac{m}{z(z+m)},\qquad \left|m+\frac{1}{z}\right|\leq\frac{|m|}{|z|(|z|-1)}\leq\frac{1}{|z|(|z|-1)^2}.$$

(c) 由 $m+m'=-z$，$\operatorname{Im}m+\operatorname{Im}m'=-\varepsilon$；由 $m'=1/m$，$\operatorname{Im}m'=-\operatorname{Im}m/|m|^2$。合起来，$\operatorname{Im}m(1-|m|^{-2})=-\varepsilon$；因 $|m|<1$，括号为负，故 $\operatorname{Im}m>0$。于是 $\operatorname{Im}m'=-\varepsilon-\operatorname{Im}m<-\varepsilon$。

(d) 令 $s=m-m'$。则 $s^2=(m+m')^2-4mm'=z^2-4$，所以 s 是 z^2-4 的平方根之一；由 (c)，$\operatorname{Im}s=\operatorname{Im}m-\operatorname{Im}m'>0$。故 $m=[(m+m')+(m-m')]/2=(-z+s)/2$，得到所给公式，其选支由此强制确定而非任意选择。

对边界值令 $z=\lambda+i\varepsilon\to\lambda$。若 $|\lambda|<2$，则 $z^2-4\to\lambda^2-4<0$，虚部为正的平方根趋于 $i\sqrt{4-\lambda^2}$。若 $|\lambda|>2$，则 $z^2-4\to\lambda^2-4>0$，且 $\operatorname{Im}(z^2-4)=2\lambda\varepsilon$，所以当 $\lambda>2$ 时从上方接近，当 $\lambda<-2$ 时从下方接近；平方根分别趋于 $+\sqrt{\lambda^2-4}$、$-\sqrt{\lambda^2-4}$，而 $m(\lambda+i0)$ 为实数。当 $\lambda=\pm2$ 时平方根趋于 0。每种情形均连续达到极限，并得到所述 $\operatorname{Im}m(\lambda+i0)$ 公式。（下面引理 4.11 仅从方程也得到相同边界值并给出速率；后续不依赖该公式。） □

注 4.10 (为何是 $-1/z$)**.** 值得不通过平方根理解 (b)。上半平面中大 z 时，(d) 的公式有 $\sqrt{z^2-4}\approx+z$（符号由虚部确定），故 $-z+\sqrt{z^2-4}$ 的两项在主阶抵消，下一阶剩下 $-1/z$：

$$\sqrt{z^2-4}=z\sqrt{1-4/z^2}=z-2/z+O(|z|^{-3}).$$

这正确但容易弄错。(b) 的证明无需跟踪分支就说明了同一件事：两根乘积为 1，一个根是 $-z$ 加有界误差，故另一个根是 $-1/z$ 加相对 $|z|^{-2}$ 阶误差。

(d) 的边界值来自公式。它们也可以直接从方程读出，这条路径还给出命题 3.7 的积分所需的一致性。对 $z=x+i\varepsilon$ 写 $m=u+iv$，则 $m^2+zm+1=0$ 化为两个实方程：

$$\text{(R)}\quad u^2-v^2+xu-\varepsilon v+1=0,\qquad\qquad \text{(I)}\quad v(2u+x)=-\varepsilon u. \tag{17}$$

引理 4.11 (从方程得到边界值)**.** 令 $\operatorname{Im}z=\varepsilon>0$，$m=u+iv$。

(a) $\operatorname{Im}m(z)=\varepsilon|m(z)|^2/(1-|m(z)|^2)$。因此 $\operatorname{Im}m>0$ 等价于 $|m|<1$，且当 $\varepsilon\downarrow0$ 时，恰在 $|m|$ 接近单位圆之处 $\operatorname{Im}m$ 保持正值。

译注： 原文末句在谱边缘需修正：$x=\pm2$ 时 $|m(x+i0)|=1$，但 $\operatorname{Im}m(x+i0)=0$。严格正的极限虚部对应 $x\in(-2,2)$；仅趋近单位圆不足以推出此结论。

(b) 设 $[a,b]\subset(-2,2)$，$\delta_0=\min_{x\in[a,b]}(1-x^2/4)>0$。对 $\varepsilon\leq\delta_0/2$ 和所有 $x\in[a,b]$，

$$\left|u+\frac{x}{2}\right|\leq\frac{\varepsilon}{\sqrt{2\delta_0}},\qquad \left|v-\frac{1}{2}\sqrt{4-x^2}\right|\leq\frac{3\varepsilon}{2\sqrt{\delta_0}}.$$

(c) 对 $|x|\geq2+\delta$，$0<v\leq\varepsilon/[(1+\delta)^2-1]$。

因此对每个 $a<b$,

$$\lim_{\varepsilon\downarrow 0}\frac{1}{\pi}\int_a^b \operatorname{Im} m(x+i\varepsilon)\,dx=\int_a^b \rho_{\mathrm{sc}}(x)\,dx,\qquad \rho_{\mathrm{sc}}(x)=\frac{1}{2\pi}\sqrt{(4-x^2)_+}.$$

证明. (a) 由 $m+m'=-z$ 得 $\operatorname{Im} m+\operatorname{Im} m'=-\varepsilon$，由 $m'=1/m$ 得 $\operatorname{Im} m'=-\operatorname{Im} m/|m|^2$，解出 $\operatorname{Im} m$。

(b) 对 (R) 配方：$v^2=(u+x/2)^2+(1-x^2/4)-\varepsilon v\ge \delta_0-\varepsilon\ge \delta_0/2$，其中使用 $0<v<1$。所以 $v\ge\sqrt{\delta_0/2}$，由 (I) 得 $|2u+x|=\varepsilon|u|/v\le \varepsilon\sqrt{2/\delta_0}$，即第一个界。接着

$$|v^2-(1-x^2/4)|\le (u+x/2)^2+\varepsilon v\le \frac{\varepsilon^2}{2\delta_0}+\varepsilon\le\frac{3}{2}\varepsilon;$$

除以 $v+\sqrt{1-x^2/4}\ge\sqrt{\delta_0/2}+\sqrt{\delta_0}\ge\sqrt{\delta_0}$ 即得第二个界。

(c) $|z|\ge|x|\ge 2+\delta$，由引理 4.9(b)，$|m|\le 1/(|z|-1)\le 1/(1+\delta)$，而 (a) 给出 $v\le \varepsilon(1+\delta)^{-2}/[1-(1+\delta)^{-2}]$。

对积分，固定 $\theta>0$，从 $[a,b]$ 中去掉距离 ±2 不超过 θ 的点。在剩余部分上，(b)、(c) 给出 $\operatorname{Im} m(x+i\varepsilon)\to\frac12\sqrt{(4-x^2)_+}$ 一致成立，所以该部分积分收敛。在去掉的部分上，长度至多 4θ，两个被积函数均介于 0 与 1 之间，故两个积分之差至多为 $4\theta/\pi$。先令 $\varepsilon\downarrow0$，再令 $\theta\downarrow0$。 □

注 4.12 (名称的由来). 在 (b) 中，极限点 $(u,v)=(-x/2,\frac12\sqrt{4-x^2})$ 满足 $u^2+v^2=1$：在支撑上，$m(x+i0)=e^{i\theta}$，其中 $x=-2\cos\theta$，密度为 $\pi^{-1}\sin\theta$。ρ_{sc} 的图像是椭圆，而当 x 从 -2 增至 2 时，$m(x+i0)$ 描出上单位半圆，密度是其高度除以 π。这就是半圆律中的半圆。

稳定性。上半平面中方程 (16) 的近似解接近 m，误差只被 ε 除一次。

引理 4.13 (固定点的稳定性). 设 $\operatorname{Im} z=\varepsilon>0$，$w\in\mathbb{C}$ 满足 $\operatorname{Im} w\ge0$ 和 $|w-1/(-z-w)|\le\delta$。则

$$|w-m(z)|\le\frac{\delta}{\varepsilon}(|z|+|w|).$$

证明. 将假设乘以 $|z+w|$ 得 $|w^2+zw+1|\le\delta|z+w|$，且 $w^2+zw+1=(w-m)(w-m')$。由引理 4.9(c)，$|w-m'|\ge\operatorname{Im} w-\operatorname{Im} m'>\varepsilon$。相除即得。 □

定理 4.14 (变换的收敛). 对 $\operatorname{Im} z=\varepsilon\in(0,1]$,

$$|\mathbb{E}m_N(z)-m(z)|\le\frac{\delta_N(\varepsilon)}{\varepsilon}\left(|z|+\frac{1}{\varepsilon}\right)\le\frac{7(|z|+\varepsilon^{-1})}{\varepsilon^5\sqrt{N}}.$$

特别地，$\mathbb{E}m_N(x+i\varepsilon)\to m(x+i\varepsilon)$ 对有界集合中的 x 一致成立。

证明. 对 $w=\mathbb{E}m_N(z)$ 应用引理 4.13，它满足 $\operatorname{Im}\mathbb{E}m_N>0$，由式 (7) 又有 $|\mathbb{E}m_N|\le1/\varepsilon$；取式 (14) 和 (15) 中的 $\delta=\delta_N(\varepsilon)$。 □

定理。命题 3.7 的全部要求现已具备。

定理 4.15 (通过 Stieltjes 变换证明半圆律). 设 M 为高斯 Wigner 矩阵，特征值为 $\lambda_1,\dots,\lambda_N$。对每个 $a<b$,

$$\mathbb{E}\left|\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}-\int_a^b\rho_{\mathrm{sc}}(x)\,dx\right|\longrightarrow0,\qquad \rho_{\mathrm{sc}}(x)=\frac{1}{2\pi}\sqrt{(4-x^2)_+}.$$

证明. 检验命题 3.7 的假设。第一条，$\mathbb{E}m_N(x+i\varepsilon)\to m(x+i\varepsilon)$ 在有界 x 集合上一致成立，是定理 4.14。第二条，$\sup_x \mathbb{E}|m_N(x+i\varepsilon)-\mathbb{E}m_N(x+i\varepsilon)|\to 0$，由命题 4.6 给出，其界 $3/(N\varepsilon^2)$ 不涉及 x。第三条，$\operatorname{Im} m\le K$ 由引理 4.9(a) 以 $K=1$ 成立。故该命题给出 $\mathbb{E}|N^{-1}\#\{\lambda_i\in(a,b)\}-\ell(a,b)|\to 0$，其中 $\ell(a,b)=\lim_{\varepsilon\downarrow 0}\pi^{-1}\int_a^b \operatorname{Im} m(x+i\varepsilon)\,dx$。剩下辨认 ℓ，引理 4.11 恰给出 $\ell(a,b)=\int_a^b \rho_{\mathrm{sc}}(x)\,dx$。 □

这再次得到定理 2.1 的更强形式——每个区间中特征值的比例在 L^1 中收敛——而密度是通过围道积分而非辨认得到的。

注 4.16 (使用了什么)**.** Wick 定理（第 5 讲）用于引理 4.4；留数定理用于命题 3.3；以及这里证明的两个事实：Schur 补和 Poincaré 不等式。除此之外没有引用别的结果。两处将期望移过积分——命题 3.7 中的 $\int_a^b dx$ 和引理 4.5 中的 $\int_0^{\pi/2} d\theta$——的被积函数均受仅依赖于 ε 的常数控制；在第一种情况下，由预解式恒等式，$x\mapsto m_N(x+i\varepsilon)$ 具有确定性的 Lipschitz 常数 ε^{-2}，故该积分是 Riemann 和的一致极限。式 (15) 中的 $N^{-1/2}$ 速率并不尖锐：真实速率为 N^{-1}，损失来自用一阶矩而非展开到二阶来约束 $\mathbb{E}|\Delta|$。

译注：这里关于两处被积函数均受确定常数控制的原说法须区分：预解式积分有该界，但 Poincaré 旋转积分含高斯 X'_θ，没有确定性界；交换由非负性 Tonelli 及梯度有界带来的可积性保证，见前述证明的译注。

注 4.17 (两个证明是同一个方程)**.** 按式 (9) 在大 $|z|$ 处展开 m，得 $m(z)=-\sum_{k\ge 0} C_k z^{-(2k+1)}$，故令 $w=z^{-2}$ 有 $-zm(z)=C(w)$。代入 Catalan 关系式 (6)，得到 $-zm=1+m^2$，即式 (16)。计数非交叉配对划分的递推式与预解式的自洽方程是同一个方程写了两次。

回到四点不足。密度直接得到了。只用了矩阵元素的二阶矩，所以不需要各阶矩。

译注： 这里的 “只用二阶矩” 可用于描述极限方程的方差参数依赖，却不是当前证明的全部假设：引理 4.4 使用高斯 Wick 四阶矩，命题 4.6 使用高斯 Poincaré。推广到一般只有有限二阶矩的系综仍需替代的集中 / 截断论证，此处没有提供。

方差不等 $\mathbb{E}M_{ij}^2=S_{ij}/N$ 将式 (16) 变成 N 个耦合方程构成的系统，而非单个方程，这是规模而非方法的变化。秩一尖峰是预解式的秩一扰动。将 $\operatorname{Im} z$ 收缩到实轴而非保持固定，恰是将整体规律转化为局部规律的办法。

习题 4.18 (A 类)**.** 取 $N=2$、$A=\begin{pmatrix}\alpha & b\\ b & d\end{pmatrix}$，其中 $d\neq 0$、$\alpha d-b^2\neq 0$。直接求 A 的逆，验证推论 4.2 的两个陈述：$(A^{-1})_{11}=1/(\alpha-b^2/d)$，且 $\operatorname{tr} A^{-1}=1/d+(A^{-1})_{11}(1+b^2/d^2)$。然后对对称 2×2 矩阵 M 取 $A=M-zI$，手工验证式 (13)：

$$\left|\operatorname{tr}(M-zI)^{-1}-\frac{1}{M_{22}-z}\right|\le\frac{1}{\operatorname{Im} z}.$$

习题 4.19 (A 类)**.** 设 M 为高斯 Wigner 矩阵，$\sigma>0$。σM 的非对角元素方差为 σ^2/N。通过重新缩放 z 而不重做任何估计，证明 σM 的变换收敛到方程 $\sigma^2m^2+zm+1=0$ 在圆盘 $|m|<1/\sigma$ 中的根，并使用引理 4.11 的论证读出极限密度 $(2\pi\sigma^2)^{-1}\sqrt{(4\sigma^2-x^2)_+}$：半径为 2σ 的半圆。矩阵元素的方差恰在一处进入方程。

习题 4.20 (B 类)**.** 完全按照命题 4.6 的证明应用引理 4.5，但取 $f(M)=\operatorname{tr} M^2=\sum_{i,j}M_{ij}^2$，证明

$$\operatorname{Var}(\operatorname{tr} M^2)\le \frac{\pi^2}{8}\left(8+\frac{8}{N}\right).$$

分别对 $i<j$ 和 $i=j$ 计算 $\partial f/\partial M_{ij}$，记住 $M_{ij}=M_{ji}$ 是一个变量。由 Wick 定理，其精确值为 $4+4/N$。重点是 Poincaré 不需任何组合计算便看出 $O(1)$——在最简单的线性统计量上体现了注 4.7 的刚性。

> **第 8 讲指定作业，第 9 讲开始时交：**习题 4.18、4.19、4.20，共三题。第二题是整讲内容的缩影。

第 9 讲推导特征值的精确联合分布，并将其读作相互排斥的电荷气体；半圆分布作为其平衡测度第三次出现。



现代机器学习中的概率

ORF 526 课程材料译稿

第 5–8 讲习题解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

解答

编号与讲义一致。C 类习题的关键思路置于框中；掌握思路后其余部分是常规推导，这也正是分类的含义。

高斯 Wigner 矩阵（第 1.3 节）

译注：本节实对数矩母函数的求导要求它在 0 邻域有限；或另用相关有限阶矩的形式递推定义累积量。均值、方差有限不能保证所有高阶累积量存在，后面的逐阶计算均须有相应存在条件，不能仅由方差假设推出任意阶结论。

1.9 (A) $M_{ij} = (A_{ij} + A_{ji})/\sqrt{2N}$，其中 A_{ab} 独立同分布且为标准高斯，故 $\mathbb{E}[A_{ab}A_{cd}] = \delta_{ac}\delta_{bd}$，且

$$\begin{aligned}\mathbb{E}[M_{ij}M_{kl}] &= \frac{1}{2N}\mathbb{E}[(A_{ij}+A_{ji})(A_{kl}+A_{lk})] \\ &= \frac{1}{2N}(\delta_{ik}\delta_{jl} + \delta_{il}\delta_{jk} + \delta_{il}\delta_{jk} + \delta_{ik}\delta_{jl}) \\ &= \frac{1}{N}(\delta_{ik}\delta_{jl} + \delta_{il}\delta_{jk}).\end{aligned}$$

当 $i=j=k=l$ 时两个 delta 项均起作用，公式给出 $2/N$。所以对角方差并非强加给模型的约定，而是 A 对称化的结果：对角元 $M_{ii} = \sqrt{2/N}A_{ii}$ 两次收集同一个高斯变量。

累积量（第 1.5* 节）

1.14 (B) 写 $K(t) = \log \mathbb{E}[e^{\sum_i t_i Y_i}]$。

(a) 对称性即混合偏导相等。为证线性，令 $\widetilde{K}(s, s', t_2, \dots, t_m) = \log \mathbb{E}\exp(sY + s'Z + \sum_{i\ge 2} t_i Y_i)$。$(aY + bZ, Y_2, \dots, Y_m)$ 的对数变换为 $K(t_1, \dots, t_m) = \widetilde{K}(at_1, bt_1, t_2, \dots, t_m)$，由链式法则（$t_1$ 只求导一次）得

$$\partial_{t_1} K = a\,\partial_s \widetilde{K} + b\,\partial_{s'}\widetilde{K}.$$

再施加 $\partial_{t_2}\cdots\partial_{t_m}$ 并令所有变量为 0，两项分别为 $a\kappa(Y, Y_2, \dots)$ 与 $b\kappa(Z, Y_2, \dots)$。给 Y_1 加常数 c 会给 K 加 ct_1，任何 $j \ge 2$ 的 ∂_{t_j} 都将其消去。在 m 个位置分别使用线性性得到 $\kappa(cY, \dots, cY) = c^m \kappa(Y, \dots, Y)$。

(b) 若各变量分成独立的两组 $B_1 \sqcup B_2$，则 $\mathbb{E}[e^{\sum t_i Y_i}]$ 分解且 $K = F_1(t_{B_1}) + F_2(t_{B_2})$。$\partial_{t_1}\cdots\partial_{t_m}$ 在两组中各含一个导数，故将两项均消去。为得可加性，用 (a) 把 $\kappa(Y+Z, \dots, Y+Z)$ 展开为 2^m 项 $\kappa(W_1, \dots, W_m)$，每个 $W_j \in \{Y, Z\}$；同时含有 Y, Z 的项均为零，仅剩 $\kappa(Y, \dots, Y) + \kappa(Z, \dots, Z)$。

(c) 在第 1–2 讲定义 1.3 中取 $\xi = it$ 得 $K(t) = \frac{1}{2}t^\top \Sigma t$，它是二次型：一阶导在 0 处为零，二阶导为 Σ_{ab}，所有更高阶导恒为零。

1.15（B）

> 多线性将 $\kappa(S_n,\dots,S_n)$ 展开为 n^m 个 X_i 的联合累积量，独立性消去所有非对角项。

由习题 1.14(a)，可去掉中心化并从 m 个位置各提出一个 $n^{-1/2}$：

$$\kappa(S_n,\dots,S_n)=n^{-m/2}\sum_{i_1,\dots,i_m=1}^{n}\kappa(X_{i_1},\dots,X_{i_m}).$$

若指标不全相同，可将变量分为等于 X_{i_1} 的一组和其余非空一组，二者独立，故该项由习题 1.14(b) 为零。n 个对角项均等于 $\kappa(X_1,\dots,X_1)$，所以

$$\kappa(S_n,\dots,S_n)=n^{1-m/2}\kappa(X_1,\dots,X_1).$$

$m=2$ 时指数为零，故每个 n 都有 $\kappa(S_n,S_n)=\kappa(X_1,X_1)=\sigma^2$；$m\ge 3$ 时指数为负，所有高阶累积量趋零：极限中只留下二阶累积量，正是高斯的形式。

手算两个矩（第 2.3 节）

2.6（A） $\operatorname{tr}M^{2k+1}$ 是奇数个中心联合高斯变量之积的和；定理 1.2 两两配对各因子，故每项均值为零。（也可用 $-M$ 与 M 同分布，故 $\operatorname{tr}M^{2k+1}$ 为对称随机变量。）再者 $\operatorname{tr}M=\sum_i M_{ii}$ 是 N 个独立中心变量之和，每项方差为 $2/N$，因此 $\mathbb{E}[(\operatorname{tr}M)^2]=2$。

路径、所有矩与涨落（第 2.4–2.7 节）

2.20（A） $\{1,\dots,6\}$ 的 $5!!=15$ 个配对划分中，十个包含交叉对（例如 $\{13\}\{24\}\{56\}$ 在 $1<2<3<4$ 处交叉），五个不交叉。对于这五个配对，从顶点 r 出发的树路径分别为

$\{12\}\{34\}\{56\}$：$r\to a\to r\to b\to r\to c\to r$　　从 r 出发的三条边，

$\{12\}\{36\}\{45\}$：$r\to a\to r\to b\to c\to b\to r$　　一条边，随后长为二的路径，

$\{14\}\{23\}\{56\}$：$r\to a\to b\to a\to r\to c\to r$　　长为二的路径，随后一条边，

$\{16\}\{23\}\{45\}$：$r\to a\to b\to a\to c\to a\to r$　　一条边，随后从其端点出发两次，

$\{16\}\{25\}\{34\}$：$r\to a\to b\to c\to b\to a\to r$　　长为三的路径，往返.

每条均访问 r,a,b,c 四个顶点，即 $k=3$ 时的 $k+1$ 个顶点。

2.21 (B) ρ_{sc} 是偶函数，故奇数阶矩为零。换元 $x=2\sin\theta$，在 $\theta\in[-\pi/2,\pi/2]$ 上有 $\sqrt{4-x^2}=2\cos\theta$、$dx=2\cos\theta\,d\theta$，故

$$\int_{-2}^{2}x^{2k}\rho_{\mathrm{sc}}(x)\,dx=\frac{4^{k+1}}{2\pi}\int_{-\pi/2}^{\pi/2}\sin^{2k}\theta\cos^2\theta\,d\theta.$$

$k=0$ 时积分 $\int\cos^2=\pi/2$，得到 $4(\pi/2)/(2\pi)=1$，故 ρ_{sc} 是概率密度。$k=1$ 时原文写[1]

$$\int_{-\pi/2}^{\pi/2}\sin^2\theta\cos^2\theta\,d\theta=\frac{1}{8}\int_{-\pi/2}^{\pi/2}\sin^2 2\theta\,d\theta=\pi/8.$$

[1]原式保留，但 $\sin^2\theta\cos^2\theta=\frac{1}{4}\sin^2(2\theta)$，不是原印的 $1/8$。相应积分为 $\pi/8$；若沿用 $1/8$ 则会得 $\pi/16$。后面的半圆矩结果正确。

由此得 $16(\pi/8)/(2\pi) = 1 = C_1$。$k = 2$ 时 $\int_{-\pi/2}^{\pi/2} \sin^4\theta\cos^2\theta\, d\theta = \pi/16$，得 $64(\pi/16)/(2\pi) = 2 = C_2$。

Stieltjes 变换（第 3 节）

3.11（A）

(a) $M = 0$：每个 $\lambda_i = 0$，故 $m_N(z) = -1/z$。

(b) 一半位于 ± 1：

$$m_N(z) = \frac{1}{2}\left(\frac{1}{-1-z} + \frac{1}{1-z}\right) = \frac{-z}{z^2-1}.$$

两种情形下，对实数 λ_i 有 $|\lambda_i - z| \geq \operatorname{Im} z$，故 $|m_N(z)| \leq 1/\operatorname{Im} z$，即式 (7)。又

$$\frac{1}{\lambda - z} = -\frac{1}{z}\left(1 - \frac{\lambda}{z}\right)^{-1} = -\frac{1}{z} - \frac{\lambda}{z^2} - \cdots,$$

对 i 取平均得到 $m_N(z) = -1/z - (\operatorname{tr} M/N)/z^2 + O(|z|^{-3})$；两例中 $\operatorname{tr} M = 0$，故第二项消失。

3.12（A） $\epsilon = 1$ 时曲线是宽峰——宽度为 1 的 Cauchy 核平滑后的半圆律，过于平滑以至于看不出 ± 2 处边缘。$\epsilon = 0.1$ 时它紧随 ρ_{sc}，包括边缘；核仍在约 $\epsilon N \approx 200$ 个特征值上取平均。$\epsilon = 0.001$ 时各特征值分辨为高度约 $1/(\pi N\epsilon)$ 的尖峰。交叉尺度为体区平均间距 $\epsilon \sim 1/N$：大于该尺度时预解式看到分布，小于该尺度时看到样本。

3.13（B） 令 $z = \lambda + i\epsilon$，则

$$\frac{1}{\lambda_i - z} = \frac{1}{(\lambda_i - \lambda) - i\epsilon} = \frac{(\lambda_i - \lambda) + i\epsilon}{(\lambda_i - \lambda)^2 + \epsilon^2},$$

其虚部为 $\epsilon/[(\lambda_i - \lambda)^2 + \epsilon^2] > 0$。对 i 取平均得到题中公式，每项为正说明上半平面内 $\operatorname{Im} m_N > 0$。乘以 ϵ 得

$$\epsilon \operatorname{Im} m_N(\lambda + i\epsilon) = \frac{1}{N}\sum_{i=1}^{N} \frac{\epsilon^2}{(\lambda_i - \lambda)^2 + \epsilon^2}.$$

这是有限和：$\lambda_i = \lambda$ 时对应项为 1，否则趋零。因此极限为满足 $\lambda_i = \lambda$ 的指标个数除以 N；该和只有 N 项，无需收敛定理。

对于图像，$\operatorname{Im} m_N$ 的第 i 项是以 λ_i 为中心、高度 $1/(N\epsilon)$、宽度 ϵ 的峰，故 $\pi^{-1}\operatorname{Im} m_N(\lambda + i\epsilon)$ 约为 $1/(N\epsilon)$ 乘以距 λ 不超过 ϵ 的特征值数目。体区中这一数目约为 $N\rho_{\mathrm{sc}}(\lambda)\epsilon$，只有 $N\epsilon \gg 1$ 时才是稳定平均。$\epsilon \ll 1/N$ 时最近的特征值占主导，图像是高度 $1/(\pi N\epsilon)$ 的尖峰梳，即习题 3.12 中的交叉。

用 Stieltjes 变换证明半圆律（第 4 节）

4.22（A） 有

$$A^{-1}=\frac{1}{\alpha d-b^2}\begin{pmatrix} d & -b \\ -b & \alpha \end{pmatrix}.$$

左上角为 $d/(\alpha d-b^2)=1/(\alpha-b^2/d)$，迹为 $(\alpha+d)/(\alpha d-b^2)$，迹恒等式右侧为

$$\frac{1}{d}+\frac{d}{\alpha d-b^2}\left(1+\frac{b^2}{d^2}\right)=\frac{(\alpha d-b^2)+(d^2+b^2)}{d(\alpha d-b^2)}=\frac{\alpha+d}{\alpha d-b^2}.$$

对 $A=M-zI$，其中 M 是对称 2×2 矩阵，令

$$g=(A^{-1})_{11}=\left(M_{11}-z-\frac{M_{12}^2}{M_{22}-z}\right)^{-1},\quad \operatorname{tr}A^{-1}-\frac{1}{M_{22}-z}=g\left(1+\frac{M_{12}^2}{(M_{22}-z)^2}\right).$$

令 $t=\operatorname{Im}[M_{12}^2/(M_{22}-z)]=M_{12}^2\operatorname{Im}z/|M_{22}-z|^2\geq 0$，$g$ 的分母虚部为 $-\operatorname{Im}z-t$，故 $|g|\leq 1/(\operatorname{Im}z+t)$；同时

$$\left|1+\frac{M_{12}^2}{(M_{22}-z)^2}\right|\leq 1+\frac{M_{12}^2}{|M_{22}-z|^2}=1+\frac{t}{\operatorname{Im}z}.$$

二者之积至多为 $(1+t/\operatorname{Im}z)/(\operatorname{Im}z+t)=1/\operatorname{Im}z$，即 $N=2$ 时的式 (14)。

4.23（A） 若 λ_i 是 M 的特征值，则 $\sigma\lambda_i$ 是 σM 的特征值，故其变换为 $N^{-1}\sum_i(\sigma\lambda_i-z)^{-1}=\sigma^{-1}m_N(z/\sigma)$。由于 $\operatorname{Im}(z/\sigma)=\operatorname{Im}z/\sigma>0$，定理 4.1(b) 在 z/σ 处给出 $\mathbb{E}[\sigma^{-1}m_N(z/\sigma)]\to\sigma^{-1}m(z/\sigma)=:m_\sigma(z)$，且在有界的 $\operatorname{Re}z$ 集合上一致。令 $w=z/\sigma$，将 $m(w)=\sigma m_\sigma(z)$ 代入 $m(w)^2+wm(w)+1=0$ 得 $\sigma^2m_\sigma^2+zm_\sigma+1=0$。又 $|m_\sigma|=|m|/\sigma<1/\sigma$。求解得

$$m_\sigma(z)=\frac{-z+\sqrt{z^2-4\sigma^2}}{2\sigma^2},$$

根取虚部为正的分支。

求密度时，在实轴上系数为实数，若 $\operatorname{Im}m_\sigma\neq 0$，两个根互为共轭，其乘积为 $1/\sigma^2$，故 $|\sigma m_\sigma|=1$。写 $\sigma m_\sigma=e^{i\theta}$，将 $\sigma^2m_\sigma^2+xm_\sigma+1=0$ 除以 $\sigma e^{i\theta}$ 得 $\sigma e^{i\theta}+x+\sigma e^{-i\theta}=0$，故 $x=-2\sigma\cos\theta$，且

$$\operatorname{Im}m_\sigma=\frac{\sin\theta}{\sigma}=\frac{1}{\sigma}\sqrt{1-\frac{x^2}{4\sigma^2}}=\frac{1}{2\sigma^2}\sqrt{4\sigma^2-x^2}.$$

除以 π 得支撑在 $[-2\sigma,2\sigma]$ 上的密度。命题 3.7 将其转化为 σM 特征值在每个区间中的比例，正如定理 4.19。

4.24（B） 独立变量为 M_{ij}，$i\leq j$。由于 $f=\sum_{i,j}M_{ij}^2=\sum_i M_{ii}^2+2\sum_{i<j}M_{ij}^2$，有 $i<j$ 时 $\partial f/\partial M_{ij}=4M_{ij}$，且 $\partial f/\partial M_{ii}=2M_{ii}$。Poincaré 求和为

$$\begin{aligned}\sum_{i<j}\frac{1}{N}\mathbb{E}(4M_{ij})^2+\sum_i\frac{2}{N}\mathbb{E}(2M_{ii})^2&=\frac{16}{N}\binom{N}{2}\frac{1}{N}+\frac{8}{N}\cdot N\cdot\frac{2}{N}\\&=8\left(1-\frac{1}{N}\right)+\frac{16}{N}=8+\frac{8}{N},\end{aligned}$$

引理 4.2 再将它乘以 $\pi^2/8$。虽然 $\operatorname{tr} M^2$ 是 N^2 项之和，该界仍为 $O(1)$；精确方差 $4 + 4/N$ 比它小一个因子 $\pi^2/2$ 和粗糙常数。[2]Poincaré 不等式看到的是 N^2 个偏导各为 $N^{-1/2}$ 量级，其平方和为 $O(1)$——机制与命题 4.3 相同，只是以 M 代替 R^2。

译注：原文末句把原始坐标和方差加权求和混在一起：约 N^2 个 M_{ij} 导数的典型大小为 $N^{-1/2}$，未加权的期望平方和为 $O(N)$；乘以元素方差 $1/N$（对角为 $2/N$）后的 Poincaré 和才为 $O(1)$，正如上面的正确计算。标准化高斯坐标还需链式缩放。

[2]按本页列出的界 $(\pi^2/8)(8 + 8/N)$ 与精确方差 $4 + 4/N$，两者之比为 $\pi^2/4$；原文的因子表述保留以待核。



现代机器学习中的概率

ORF 526 课程材料译稿

第 9–11 讲：高斯过程（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 高斯过程

第 9–11 讲：高斯过程
特征映射、最大值及指标集的几何。

纲要： 第 9 讲：定义 $\longrightarrow$ 特征映射：核是内积 $\longrightarrow$ 例子：球面上的 Mu、Brown 运动、宽网络 $\longrightarrow$ 最大值：无论是否独立，均有 $\sqrt{2\log n}$ 的上界。
第 10 讲：上确界：独立高斯变量达到 $\sqrt{2\log n}$ $\longrightarrow$ 覆盖数 $\longrightarrow$ Dudley 不等式：陈述、球面、用链化法证明 $\longrightarrow$ 陈述 Sudakov 下界。
第 11 讲（计划）：比较：通过高斯插值证明 Sudakov–Fernique 和 Slepian 不等式 $\longrightarrow$ 算子范数 $\mathbb{E}\|M\| \le \sqrt{N}+\sqrt{d}$ $\longrightarrow$ 证明 Sudakov 下界 $\longrightarrow$ 期中考试范围。
阅读指南： 两个事实放在方框中引用，每讲一个。习题分 A 类（是否跟上讲课）、B 类（是否理解论证）和 C 类（自行建立一个小理论）。

问题： 什么是高斯过程，首先应询问它的什么性质?
它是以任意集合 T 为指标的高斯向量。其协方差 $\Sigma_{s,t}$ 是特征的内积 $\langle\phi(s),\phi(t)\rangle$，因此该过程是通过一个标准高斯变量看到的集合 $\{\phi(t)\}$。基本量是 $\mathbb{E}\sup_t X_t$。

我们已经遇到过两个高斯过程：宽随机网络在有限个输入上的输出（第 3 讲），即协方差为 $\Sigma_{x,x'}=\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)]$ 的高斯向量；以及高斯矩阵 M 所定义的 $u\mapsto Mu$（第 5 讲），当时对固定 u 计算了 $\mathbb{E}\|Mu\|^2$。第 9–11 讲给出 $\sup_u\|Mu\|$ 即算子范数的界，更一般地，给出高斯过程在其指标集上的最大值的界。

1.1 定义

定义 1.1 (高斯过程)**.** 设 T 为任意集合。若实随机变量族 $X=\{X_t\}_{t\in T}$ 对每个有限组 $t_1,\dots,t_n\in T$，向量 $(X_{t_1},\dots,X_{t_n})$ 都是第 1–2 讲定义 1.3 意义下的高斯向量，则称 X 为高斯过程；等价地，由该讲推论 1.7，只需每个有限线性组合 $\sum_j a_jX_{t_j}$ 都是一维高斯变量。其均值函数和协方差核为

$$\mu_t=\mathbb{E}X_t,\qquad \Sigma_{s,t}=\operatorname{Cov}(X_s,X_t).$$

若 $\mu\equiv 0$ 则称过程中心化。下文除非另作说明，所有过程均为中心化的。

X 的每个有限维边缘分布均由 μ,Σ 确定，且不会用到 X 的其他性质。

引理 1.2 (核为半正定)**.** 对每组 $t_1,\dots,t_n\in T$ 和 $a\in\mathbb{R}^n$，

$$\sum_{j,k}a_ja_k\Sigma_{t_j,t_k}\ge 0.$$

证明. 它是 $\operatorname{Var}(\sum_j a_jX_{t_j})$。 □

逆命题——每个半正定的 Σ 都是某个高斯过程的核——在第 1.2 节陈述。

1.2 特征映射：核是内积

若 $\phi : T \to \mathbb{R}^k$ 是任意映射，$g \sim \mathcal{N}(0, I_k)$，则

$$X_t = \langle \phi(t), g \rangle \tag{1}$$

是高斯过程：任意有限集合 $(X_{t_1}, \dots, X_{t_n})$ 是 g 的线性像 Ag，其中 A 的各行为 $\phi(t_j)$，故由第 1–2 讲定理 1.5 它为高斯向量，协方差为 $AA^\top$，即

$$\Sigma_{s,t} = \langle \phi(s), \phi(t) \rangle.$$

映射 ϕ 是 Σ 的特征映射。

在一些例子中 $\phi(t)$ 是函数而非向量，H 是 Hilbert 空间：具有内积且可以取极限的空间。此处有三种：$\mathbb{R}^k$；$L^2[0,1]$，即 $[0,1]$ 上平方可积函数构成的空间，内积为 $\langle f, h \rangle = \int_0^1 fh$；以及高斯分布的 L^2，即高斯向量 w 的函数构成的空间，内积为 $\langle f, h \rangle = \mathbb{E}[f(w)h(w)]$。每个都可看作允许 k 为无穷大的 $\mathbb{R}^k$：对 H 的正交归一基 $e_1, e_2, \dots$ 和独立同分布的标准高斯变量 $g_1, g_2, \dots$，式 (1) 写为 $X_t = \sum_i \langle \phi(t), e_i \rangle g_i$，它收敛，因为 $\sum_i \langle \phi(t), e_i \rangle^2 = \|\phi(t)\|^2 < \infty$。我们在每种情形均写作 $X_t = \langle \phi(t), g \rangle$。

译注： 无限维时此为柱状 / 等距高斯过程的标量记号：对每个固定 t，所示标量级数在 L^2 收敛；$\sum_i g_i e_i$ 一般不是 H 值向量，因为 $\sum_i g_i^2 = \infty$ 几乎必然。可数基论证直接适用于可分 H；一般核的非可分情形不能只凭这串可数展开处理。该计算不证明全体 t 同时的路径收敛。

> 引用：特征映射产生过程，每个核都有特征映射
>
> (i) 若 $\phi : T \to H$ 是到 Hilbert 空间的任意映射，则 $X_t = \langle \phi(t), g \rangle$ 是中心高斯过程，核为 $\Sigma_{s,t} = \langle \phi(s), \phi(t) \rangle$。(ii) 反过来，$T$ 上每个对称半正定 Σ 都可对某个 Hilbert 空间 H 和某个 $\phi : T \to H$ 表成此形式。$H = \mathbb{R}^k$ 时的 (i) 就是上面的论证；(ii) 是 Moore–Aronszajn 定理。下文每个核都带有显式特征映射，因此不使用 (ii)。

注 1.3 (过程记住了什么)**.** ϕ 和 $U\phi$（U 是 H 的旋转）给出相同的核，从而给出相同的过程。过程只通过特征集 $\{\phi(t) : t \in T\}$ 的几何依赖于 ϕ：长度 $\|\phi(t)\|^2 = \Sigma_{t,t}$、距离、角度、凸包。最大值（第 1.5 节）和零点集（习题 1.16）是该几何的两个函数。

1.3 例子

例 1.4 (有限指标集)**.** 令 $T = \{1, \dots, n\}$，Σ 为 $n \times n$ 协方差矩阵。写 $\Sigma = AA^\top$，令 $\phi(j)$ 为 A 的第 j 行。则 $X_j = \langle \phi(j), g \rangle = (Ag)_j$：高斯向量的特征映射是其协方差矩阵的平方根。

例 1.5 (通过高斯矩阵看球面)**.** 设 M 为 $N \times d$ 矩阵，元素独立同分布于 $\mathcal{N}(0,1)$，令 $T = S^{d-1}$ 为 $\mathbb{R}^d$ 中的单位球面。对 $u \in T$ 令 $X_u = Mu \in \mathbb{R}^N$。每个坐标为 $(Mu)_i = \langle M_i, u \rangle$，其中 M_i 为第 i 行，所以对任意 u, v, i, j，

$$\mathbb{E}[(Mu)_i (Mv)_j] = \sum_{k,l} u_k v_l \mathbb{E}[M_{ik} M_{jl}] = \delta_{ij} \langle u, v \rangle.$$

这 N 个坐标过程是球面上同一个标量过程的独立副本，其核为 $\Sigma_{u,v}=\langle u,v\rangle$，特征映射是恒等映射 $\phi(u)=u\in\mathbb{R}^d$：该过程为 $u\mapsto\langle g,u\rangle$，其中只有一个 $g\sim\mathcal{N}(0,I_d)$，而特征集就是球面本身。其最大值是显式的：

$$\sup_{u\in S^{d-1}}\langle g,u\rangle=\|g\|,$$

在 $u=g/\|g\|$ 时取到。整个矩阵对应以 $S^{N-1}\times S^{d-1}$ 为指标的过程 $Y_{(u,v)}=\langle v,Mu\rangle=\sum_{ij}v_iM_{ij}u_j$，其核为 $\langle v,v'\rangle\langle u,u'\rangle$，特征映射为 $\phi(u,v)=vu^\top$，即 Frobenius 范数为 1 的秩一矩阵；其最大值为算子范数，

$$\sup_{u,v}\langle v,Mu\rangle=\|M\|_{\mathrm{op}}=\sup_u\|Mu\|.$$

对固定单位向量 u，$\mathbb{E}\|Mu\|^2=N$；第 11 讲证明 $\mathbb{E}\|M\|_{\mathrm{op}}\le\sqrt{N}+\sqrt{d}$。

例 1.6 (Brown 运动)**.** 取 $T=[0,1]$、$H=L^2[0,1]$，令 $\phi(t)=\mathbf{1}_{[0,t]}$，即 $[0,t]$ 的指示函数。则

$$\Sigma_{s,t}=\int_0^1\mathbf{1}_{[0,s]}\mathbf{1}_{[0,t]}=\min(s,t),$$

具有此核的过程 B_t 是 Brown 运动：$B_0=0$，$B_t\sim\mathcal{N}(0,t)$，且不交区间上的增量独立，因为当 $r\le s$ 时 $\mathbf{1}_{(s,t]}$ 与 $\mathbf{1}_{[0,r]}$ 正交（习题 1.12）。特征是指示函数，两个特征之间的距离为 $\|\mathbf{1}_{[0,t]}-\mathbf{1}_{[0,s]}\|=\sqrt{|t-s|}$。

例 1.7 (宽网络)**.** 第 3 讲命题 1.24：对输入 $x\in\mathbb{R}^d$、权重 $w\sim\mathcal{N}(0,I_d)$ 和满足 $\mathbb{E}\sigma(\langle w,x\rangle)^2<\infty$ 的激活函数 σ，宽随机网络在有限个输入处的输出收敛到高斯向量，其核为

$$\Sigma_{x,x'}=\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)].$$

特征映射为

$$\phi(x)=\sigma(\langle\,\cdot\,,x\rangle)\in H=L^2(\mathcal{N}(0,I_d)),$$

即将 x 处的激活看作权重 w 的函数；于是 $\langle\phi(x),\phi(x')\rangle=\mathbb{E}[\sigma(\langle w,x\rangle)\sigma(\langle w,x'\rangle)]$ 恰为 $\Sigma_{x,x'}$。第 3 讲的极限是具有此特征映射的高斯过程。对数据条件化就是将第 1–2 讲定理 2.9 用于矩阵 $(\Sigma_{x_i,x_j})_{ij}$：精确贝叶斯推断下的无限宽网络是核为 Σ 的核回归（习题 1.13 为 Brown 运动做此计算）。

1.4 典范度量

定义 1.8. 中心高斯过程的典范度量为

$$d(s,t)=\|X_s-X_t\|_{L^2}=(\mathbb{E}(X_s-X_t)^2)^{1/2}=\sqrt{\Sigma_{s,s}-2\Sigma_{s,t}+\Sigma_{t,t}}.$$

通过特征映射，$d(s,t)=\|\phi(s)-\phi(t)\|$。在球面上（例 1.5）它是欧氏距离 $\|u-v\|$；对 Brown 运动它是 $\sqrt{|t-s|}$。第 10 讲用这一度量来约束过程的最大值。

译注：典范距离一般只是伪度量，不同指标可距离为 0。协方差确定有限维分布，不能单独确定任意版本的路径上确界；Brown 运动的反射原理 / 路径最大值使用连续、可分版本。本文期望上确界保留后面式 (2) 对有限子集最大值取上确界的定义，不擅自替换成任意版本的路径上确界。

1.5 最大值

固定 T 上的中心高斯过程。对有限的 T，最大值 $\max_t X_t$ 是普通随机变量；对一般 T，定义

$$\mathbb{E}\sup_{t\in T} X_t := \sup\{\mathbb{E}\max_{t\in F} X_t : F\subset T \text{ 有限}\}, \tag{2}$$

它可能为 $+\infty$，且只涉及有限维边缘分布。

命题 1.9 (并集界)**.** 设 $X_1,\dots,X_n$ 为中心高斯变量，不必独立，且 $\operatorname{Var} X_i \le \sigma^2$。则

$$\mathbb{E}\max_{i\le n} X_i \le \sigma\sqrt{2\log n}.$$

证明. 对 $\lambda>0$，先用 Jensen 不等式，再对正数的最大值使用并集界，

$$e^{\lambda\mathbb{E}\max_i X_i} \le \mathbb{E}e^{\lambda\max_i X_i} = \mathbb{E}\max_i e^{\lambda X_i} \le \sum_i \mathbb{E}e^{\lambda X_i} = \sum_i e^{\lambda^2\operatorname{Var} X_i/2} \le n e^{\lambda^2\sigma^2/2}.$$

取对数得 $\mathbb{E}\max_i X_i \le (\log n)/\lambda + \lambda\sigma^2/2$，再取 $\lambda=\sqrt{2\log n}/\sigma$。 □

该界不使用独立性。对独立的 X_i 它是尖锐的（命题 2.1），相关性则降低最大值（习题 1.15(a)）。在例 1.5 的球面上，$\mathbb{E}\sup_u\langle g,u\rangle = \mathbb{E}\|g\| \in [\sqrt{d}-1,\sqrt{d}]$（习题 1.10），即并集界对 $n=e^{d/2}$ 个点所给出的值。通过特征映射，$\sup_t X_t = \sup_{h\in S}\langle h,g\rangle$，其中 S 是特征集；其期望称为 S 的高斯宽度（习题 1.14）。

1.6 接下来是什么

(i) 链化（第 10 讲）。若典范度量下半径为 ε 的 $N(\varepsilon)$ 个球覆盖 T，则由 Dudley 不等式，

$$\mathbb{E}\sup X \le 12\int_0^\infty \sqrt{\log N(\varepsilon)}\,d\varepsilon.$$

在球面上，该界在相差常数因子的意义下为 $\sqrt{d}$。Sudakov 不等式是用 $N(\varepsilon)$ 表示的下界。

(ii) 比较（第 11 讲）。若对所有 s,t 有 $d_X(s,t)\le d_Y(s,t)$，则 $\mathbb{E}\sup X \le \mathbb{E}\sup Y$（Sudakov–Fernique），证明用高斯插值和分部积分（第 5 讲）。它给出 Sudakov 不等式及 $\mathbb{E}\|M\|_{\mathrm{op}} \le \sqrt{N}+\sqrt{d}$。

习题 1.10 (A 类)**.** 设 M 为元素独立同分布于 $\mathcal{N}(0,1)$ 的 $N\times d$ 矩阵。

(a) 验证 $\mathbb{E}[(Mu)_i(Mv)_j] = \delta_{ij}\langle u,v\rangle$，并推得对单位向量 u,v，二元组 Mu, Mv 联合高斯，且 $\mathbb{E}\langle Mu,Mv\rangle = N\langle u,v\rangle$。

(b) 对 $g\sim\mathcal{N}(0,I_d)$，证明 $\sup_{u\in S^{d-1}}\langle g,u\rangle = \|g\|$，且 $\mathbb{E}\|g\|\le\sqrt{d}$。

(c) 证明 $\mathbb{E}\|g\|\ge\sqrt{d}-1$。计算 $\mathbb{E}\|g\|^4 = d^2+2d$ 并使用 $\mathbb{E}Y^2 \le (\mathbb{E}Y)^{2/3}(\mathbb{E}Y^4)^{1/3}$。当 $d=100$ 时，真实值为 9.975。

习题 1.11 (A 类)**.** 核的组合。设 Σ_1,Σ_2 是 T 上的核，特征映射 ϕ_1,ϕ_2 分别映到 $\mathbb{R}^{k_1},\mathbb{R}^{k_2}$。

(a) 写出 $\Sigma_1+\Sigma_2$ 和乘积 $\Sigma_1\Sigma_2$ 的特征映射，故两者都是核。

(b) 推得对每个 m，$\langle u,v\rangle^m$ 都是 $\mathbb{R}^d$ 上的核。

(c) 显式写出核为 $\langle u,v\rangle^2$ 的高斯过程：它是 $u\mapsto u^\top Gu$，其中 G 是元素独立同分布为高斯变量的 $d\times d$ 矩阵。

在 (a) 中，将两个特征向量叠放可得和的映射；取 k_1k_2 个乘积 $\phi_1(t)_a\phi_2(t)_b$ 可得乘积的映射。

习题 1.12 (A 类)**.** Brown 运动在 $[0,1]$ 上有 $\Sigma_{s,t}=\min(s,t)$。

(a) 检验在 $L^2[0,1]$ 中 $\langle \mathbf{1}_{[0,s]},\mathbf{1}_{[0,t]}\rangle=\min(s,t)$。

(b) 证明对 $0\le r\le s\le t\le 1$，增量 $B_t-B_s\sim\mathcal{N}(0,t-s)$ 且与 B_r 独立。计算一个协方差，再使用第 1–2 讲定理 1.16。

习题 1.13 (B 类)**.** 将高斯过程对有限个取值条件化，就是对矩阵 $(\Sigma_{t_i,t_j})_{ij}$ 应用第 1–2 讲定理 2.9。

(a) 对 Brown 运动计算 $t\in[0,1]$ 时的 $\mathbb{E}[B_t\mid B_1]$ 和 $\operatorname{Var}(B_t\mid B_1)$。

(b) 改为对 $B_{t_1},\dots,B_{t_n}$ 条件化，其中 $0<t_1<\cdots<t_n<1$，并证明 $t\mapsto\mathbb{E}[B_t\mid B_{t_1},\dots,B_{t_n}]$ 是观测值的分段线性插值。先猜答案，再检验 B_t-(猜测) 与每个 B_{t_j} 不相关；独立增量可以完成这项工作。(a) 中的过程 B_t-tB_1 是 Brown 桥。

习题 1.14 (C 类)**.** 高斯宽度。对 $S\subset\mathbb{R}^k$ 定义

$$w(S)=\mathbb{E}\sup_{h\in S}\langle h,g\rangle,\qquad g\sim\mathcal{N}(0,I_k).$$

(a) 对特征映射为 $\phi:T\to\mathbb{R}^k$ 的过程，说明 $\mathbb{E}\sup_{t\in T}X_t=w(S)$，其中 $S=\{\phi(t):t\in T\}$：过程的期望最大值是其特征集的宽度。

(b) 证明以下规则：$w(S)\ge 0$；$S\subset S'\Rightarrow w(S)\le w(S')$；$w(S+x)=w(S)$，且对 $\lambda\ge0$ 有 $w(\lambda S)=\lambda w(S)$；$w(\operatorname{conv}S)=w(S)$。

(c) 计算三个宽度。记 B_2^k,B_1^k,B_∞^k 为欧氏、ℓ^1 和 ℓ^∞ 范数的单位球，证明

$$w(B_2^k)=\mathbb{E}\|g\|_2\in[\sqrt{k}-1,\sqrt{k}],$$
$$w(B_1^k)=\mathbb{E}\max_i|g_i|\le\sqrt{2\log(2k)},\qquad w(B_\infty^k)=\mathbb{E}\|g\|_1=k\sqrt{\frac{2}{\pi}}.$$

每种情况下 $\langle h,g\rangle$ 在单位球上的上确界是 g 的一个范数。对 B_2^k 用习题 1.10；对 B_1^k，将命题 1.9 应用于 $2k$ 个高斯变量 $\pm g_i$。

(d) 设 $S_k\subset\mathbb{R}^d$ 为至多有 k 个非零分量的单位向量，证明 $w(S_k)\le\sqrt{k}\sqrt{2\log(2d)}$。对高斯方向而言，$k$ 稀疏单位向量的维数是 $k\log d$，而非 d。

习题 1.15 (B 类)**.** 最大值可以小的两种方式。

(a) 设 $g_0, g_1, \dots, g_n$ 独立同分布于 $\mathcal{N}(0,1)$，固定 $\rho \in [0,1]$，令 $X_i = \sqrt{\rho}\, g_0 + \sqrt{1-\rho}\, g_i$。计算 $(X_1, \dots, X_n)$ 的核，并证明 $\mathbb{E}\max_i X_i = \sqrt{1-\rho}\,\mathbb{E}\max_i g_i$：相关性使最大值缩小，并在 $\rho = 1$ 时将它消去。

(b) 设 $u_1, \dots, u_n$ 为 $\mathbb{R}^d$ 中的单位向量，$X_i = \langle u_i, g\rangle$。证明 $\mathbb{E}\max_i X_i \le \min(\sqrt{2\log n}, \mathbb{E}\|g\|)$。什么样的 u_i 配置使第一个界基本尖锐，什么样的配置使第二个界基本尖锐？同一个最大值的两个界：来自计数的 $\sqrt{2\log n}$ 和来自几何的 $\sqrt{d}$。

习题 1.16 (B 类)**.** 过程的零点集是其特征集的随机截片。设 $\phi : T \to \mathbb{R}^k$ 且对所有 t 都有 $\phi(t) \neq 0$，$g \sim \mathcal{N}(0, I_k)$，$X_t = \langle \phi(t), g\rangle$。

(a) 证明 $\{t : X_t = 0\} = \{t : \phi(t) \in g^{\perp}\}$，其中 $g^{\perp}$ 是过原点且法向量为 g 的超平面，并证明 $g^{\perp}$ 是均匀随机超平面：其分布在 $\mathbb{R}^k$ 的每个旋转下不变。

(b) 现令 $T = [a,b]$，ϕ 光滑，$\gamma(t) = \phi(t)/\|\phi(t)\|$ 是投影到单位球面上的特征曲线。证明

$$\mathbb{E}\#\{t \in [a,b] : X_t = 0\} = \frac{1}{\pi}\,\mathrm{length}(\gamma).$$

由 (a)，这等于 γ 穿过随机超平面的期望次数。由旋转不变性和可加性，长度为 ℓ 的大圆弧的该数目为 $c\ell$；完整大圆恰好穿过超平面两次，由此得到 c。光滑曲线是此类弧的极限。

(c) 将 (b) 应用于随机三角多项式 $X_\theta = \sum_{j=1}^{n}(a_j \cos j\theta + b_j \sin j\theta)$，$\theta \in [0, 2\pi)$，其中所有 a_j, b_j 独立同分布于 $\mathcal{N}(0,1)$：辨认 ϕ，检验 $\|\phi(\theta)\|$ 为常数，并推得零点期望数为 $2\sqrt{(n+1)(2n+1)/6} \approx 2n/\sqrt{3}$。$n = 10$ 时，模拟给出 12.44，而理论值为 12.41。

第 9 讲指定作业，第 10 讲开始时交： 习题 1.10、1.11、1.12、1.13、1.14、1.15、1.16，共七题，大多数很短。前三题检查例子；习题 1.14 建立本讲省略的一个定义；习题 1.16 是本讲没有讲到的一个小定理。

2 上确界：独立性、链化和球面

问题： 当 T 为无限集时，$\mathbb{E}\sup_{t\in T} X_t$ 有多大？
对 n 个点，并集界给出 $\sqrt{2\log n}$，对独立坐标此界尖锐。对一般 T，Dudley 不等式以典范度量中半径为 ε 的 $N(\varepsilon)$ 个球覆盖 T，并对 ε 积分 $\sqrt{\log N(\varepsilon)}$。在球面上，这给出相差常数因子的 $\sqrt{d}$；Sudakov 不等式给出匹配的下界。

本节始终设 X 为 T 上的中心高斯过程，其典范度量为 $d(s,t) = (\mathbb{E}(X_s - X_t)^2)^{1/2}$（定义 1.8），且 $\mathbb{E}\sup_t X_t$ 具有式 (2) 的含义。

2.1 独立高斯变量达到 $\sqrt{2\log n}$

命题 2.1 (独立情形)**.** 若 $g_1, \dots, g_n$ 独立同分布于 $\mathcal{N}(0,1)$，则当 $n \to \infty$ 时，

$$\mathbb{E}\max_{i\le n} g_i = \sqrt{2\log n}\,(1 + o(1)).$$

证明. 上界来自命题 1.9。对于下界，先给出尾部估计：当 $t \geq 1$ 时，

$$\begin{aligned}\mathbb{P}(g > t) &= \frac{1}{\sqrt{2\pi}} \int_t^\infty e^{-x^2/2}\, dx \geq \frac{1}{\sqrt{2\pi}} \int_t^{t+1/t} e^{-x^2/2}\, dx \\ &\geq \frac{1}{\sqrt{2\pi}\, t} e^{-(t+1/t)^2/2} \geq \frac{e^{-3/2}}{\sqrt{2\pi}\, t} e^{-t^2/2},\end{aligned}$$

因为 $(t+1/t)^2/2 = t^2/2 + 1 + 1/(2t^2) \leq t^2/2 + 3/2$。固定 $\delta \in (0,1)$，令 $t = \sqrt{(2-\delta)\log n}$。则 $n\mathbb{P}(g > t) \geq cn^{\delta/2}/t \to \infty$，故由独立性，

$$\mathbb{P}\left(\max_i g_i \leq t\right) = (1 - \mathbb{P}(g > t))^n \leq e^{-n\mathbb{P}(g>t)} \longrightarrow 0.$$

最后，在事件 $\{\max_i g_i > t\}$ 上 $\max_i g_i \geq t$，且始终有 $\max_i g_i \geq g_1 \geq -g_1^-$，因此

$$\begin{aligned}\mathbb{E} \max_i g_i &\geq t\, \mathbb{P}\left(\max_i g_i > t\right) - \mathbb{E} g_1^- \\ &= \sqrt{(2-\delta)\log n}\,(1 - o(1)) - \frac{1}{\sqrt{2\pi}}.\end{aligned}$$

除以 $\sqrt{2\log n}$，先令 $n \to \infty$，再令 $\delta \downarrow 0$。 □

参考例子：S^{d-1} 上的 $X_u = \langle g, u\rangle$ 有 $\mathbb{E}\sup_u X_u = \mathbb{E}\|g\| \in [\sqrt{d} - 1, \sqrt{d}]$（习题 1.10），即 $n = e^{d/2}$ 时 $\sqrt{2\log n}$ 的值。典范度量为 $d(u,v) = \|u - v\|$，而球面包含 $e^{\Theta(d)}$ 个两两距离为 $1/4$ 的点（引理 2.3、习题 2.8）。

2.2 覆盖数

定义 2.2 (覆盖数)**.** 对 $\varepsilon > 0$，(T, d) 的 ε-网是子集 $T' \subset T$，使得每个 $t \in T$ 到某个 T' 中的点的距离至多为 ε。覆盖数 $N(T, d, \varepsilon)$ 是 ε-网大小的最小值（不存在有限网时为 $+\infty$）。它随 ε 非增，且当 $\varepsilon \geq \operatorname{diam}(T)$ 时 $N(T, d, \varepsilon) = 1$。

引理 2.3 (球面)**.** 对 S^{d-1} 上的欧氏度量和每个 $\varepsilon > 0$，

$$N(S^{d-1}, \|\cdot\|, \varepsilon) \leq \left(1 + \frac{2}{\varepsilon}\right)^d.$$

证明. 设 $u_1, \ldots, u_n \in S^{d-1}$ 为 ε-分离的，即 $i \neq j$ 时 $\|u_i - u_j\| > \varepsilon$，且对此性质极大：不能再加入球面上的点。极大性表明每个 $u \in S^{d-1}$ 到某个 u_i 的距离至多 ε，故 $\{u_i\}$ 为 ε-网，$N \leq n$。分离性说明欧氏球 $B(u_i, \varepsilon/2)$ 两两不交，它们都包含于球 $B(0, 1 + \varepsilon/2)$。比较体积得 $n(\varepsilon/2)^d \leq (1 + \varepsilon/2)^d$，即所求结论。 □

反过来 $N(S^{d-1}, \|\cdot\|, 1/4) \geq 2^{d-2}$（习题 2.8）。$n$ 点集合在每个尺度上均有 $N \leq n$；带度量 $\sqrt{|t-s|}$ 的 $[0,1]$ 有 $N \leq 1 + 1/(2\varepsilon^2)$（习题 2.7）。

2.3 Dudley 不等式

定理 2.4 (Dudley)**.** 对 (T, d) 上任意中心高斯过程，令 $D = \operatorname{diam}(T)$，则

$$\mathbb{E}\sup_{t \in T} X_t \leq 12 \int_0^{D/2} \sqrt{\log N(T, d, \varepsilon)}\, d\varepsilon. \tag{3}$$

当 $\varepsilon \ge D$ 时被积函数为零，故也可在 $(0,\infty)$ 上积分。对 $T=\{1,\dots,n\}$ 且 $\operatorname{Var} X_i \le \sigma^2$，有 $D \le 2\sigma$ 和 $N \le n$，因此该式给出 $\mathbb{E}\max_i X_i \le 12\sigma\sqrt{\log n}$，与命题 1.9 只差常数因子。

例 2.5 (球面)**.** 对 S^{d-1} 上 $X_u = \langle g, u\rangle$，$D=2$，由引理 2.3 得

$$\mathbb{E}\|g\| = \mathbb{E}\sup_{u\in S^{d-1}} \langle g,u\rangle \le 12\int_0^1 \sqrt{d\log(1+2/\varepsilon)}\,d\varepsilon = 12c_0\sqrt{d},$$

其中 $c_0 = \int_0^1 \sqrt{\log(1+2/\varepsilon)}\,d\varepsilon = 1.35$。$\sqrt{d}$ 的量级是尖锐的（习题 1.10），常数 16.2 则不是。对 $S^{N-1}\times S^{d-1}$ 作相同计算，得到 $N\times d$ 高斯矩阵满足 $\mathbb{E}\|M\|_{\mathrm{op}} \le C\sqrt{N+d}$（习题 2.9）。

2.4 Dudley 不等式的证明：链化

对过程在连续各层网之间的增量应用并集界。若 $\pi_k(t)$ 在 ε_k-网中逼近 t，且 $\varepsilon_k \downarrow 0$，则链为

$$X_t = X_{t_0} + \sum_{k\ge 1}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}).$$

每个链环 $X_{\pi_k(t)} - X_{\pi_{k-1}(t)}$ 的标准差至多为 $3\varepsilon_k$，无论 T 多大，在尺度 k 上至多只有 $N(\varepsilon_k)^2$ 个不同链环。该尺度的并集界代价为 $3\varepsilon_k\sqrt{2\log N(\varepsilon_k)^2}$；对 k 求和得到积分。由式 (2)，只需使用 T 的网，约束有限 $F\subset T$ 的 $\mathbb{E}\max_{t\in F} X_t$。

定理 2.4 的证明. 若积分无限则无需证明，故假设对所有 $\varepsilon>0$ 均有 $N(T,d,\varepsilon)<\infty$；于是 $D<\infty$。固定有限 $F\subset T$。

第一步：网。对 $k\ge 0$ 令 $\varepsilon_k = D2^{-k}$，取 T 的 ε_k-网 $T_k\subset T$，其大小 $|T_k| = N_k := N(T,d,\varepsilon_k)$。由于 $\varepsilon_0 = D$，可取单点 $T_0=\{t_0\}$。对每个 $t\in T$ 和 $k\ge 0$ 选 $\pi_k(t)\in T_k$，使 $d(t,\pi_k(t))\le\varepsilon_k$。于是对每个 t 和 $k\ge 1$，由三角不等式，

$$d(\pi_k(t),\pi_{k-1}(t)) \le d(\pi_k(t),t) + d(t,\pi_{k-1}(t)) \le \varepsilon_k + \varepsilon_{k-1} = 3\varepsilon_k.$$

第二步：链与每个尺度上的并集界。对 $K\ge 1$ 和 $t\in F$，

$$X_t - X_{t_0} = \sum_{k=1}^{K}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}) + (X_t - X_{\pi_K(t)}),$$

故逐项对 $t\in F$ 取最大值再取期望（并使用 $\mathbb{E}X_{t_0}=0$），

$$\mathbb{E}\max_{t\in F} X_t \le \sum_{k=1}^{K}\mathbb{E}\max_{t\in F}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}) + \mathbb{E}\max_{t\in F}(X_t - X_{\pi_K(t)}). \tag{4}$$

第 k 项中的随机变量 $X_{\pi_k(t)} - X_{\pi_{k-1}(t)}$ 只通过 $(\pi_k(t),\pi_{k-1}(t))\in T_k\times T_{k-1}$ 依赖于 t，故最大值至多涉及 $N_kN_{k-1}\le N_k^2$ 个中心高斯变量，由第一步，每个方差至多为 $9\varepsilon_k^2$。命题 1.9 给出

$$\mathbb{E}\max_{t\in F}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}) \le 3\varepsilon_k\sqrt{2\log N_k^2} = 6\varepsilon_k\sqrt{\log N_k}.$$

式 (4) 的最后一项是至多 $|F|$ 个方差至多 ε_K^2 的中心高斯变量的最大值，其期望至多为

$$\varepsilon_K\sqrt{2\log|F|}.$$

因为 F 有限，当 $K \to \infty$ 时该项趋于 0。令 $K \to \infty$，

$$\mathbb{E} \max_{t \in F} X_t \le 6 \sum_{k \ge 1} \varepsilon_k \sqrt{\log N(T, d, \varepsilon_k)}. \tag{5}$$

第三步：和转化为积分。由于 $\varepsilon_k = 2(\varepsilon_k - \varepsilon_{k+1})$，且对 $\varepsilon \le \varepsilon_k$ 有 $N(T,d,\varepsilon) \ge N(T,d,\varepsilon_k)$，

$$\varepsilon_k \sqrt{\log N_k} = 2 \int_{\varepsilon_{k+1}}^{\varepsilon_k} \sqrt{\log N_k}\, d\varepsilon \le 2 \int_{\varepsilon_{k+1}}^{\varepsilon_k} \sqrt{\log N(T,d,\varepsilon)}\, d\varepsilon.$$

对 $k \ge 1$ 求和，区间 $[\varepsilon_{k+1}, \varepsilon_k]$ 铺满 $(0, \varepsilon_1] = (0, D/2]$，式 (5) 成为

$$\mathbb{E} \max_{t \in F} X_t \le 12 \int_0^{D/2} \sqrt{\log N(T,d,\varepsilon)}\, d\varepsilon.$$

右侧不依赖 F；对有限 F 取上确界。 □

注 2.6 (证明使用了什么)**.** 只用了命题 1.9（每个尺度一次）及 d 的三角不等式。同一证明适用于任何满足 $\mathbb{E}e^{\lambda(X_s - X_t)} \le e^{\lambda^2 d(s,t)^2/2}$ 的过程（次高斯过程）。求和形式 (5) 往往比积分更方便。

译注： 次高斯推广还用了基点可积且 $\mathbb{E}X_{t_0} = 0$，或须将结论用于 $X_t - X_{t_0}$。仅增量矩母函数界不够：恒定过程 $X_t \equiv 1$ 的增量和熵积分都为 0，期望上确界却为 1。

2.5 Sudakov 下界

下界使用单个尺度上的覆盖数。

> 引用：Sudakov 不等式
>
> 存在绝对常数 $c > 0$，使对 (T,d) 上的每个中心高斯过程和每个 $\varepsilon > 0$，
>
> $$\mathbb{E} \sup_{t \in T} X_t \ge c\varepsilon \sqrt{\log N(T,d,\varepsilon)}.$$
>
> 第 11 讲通过比较证明：在一个有 n 个点的 ε-分离集上，X 的增量支配 n 个方差为 $\varepsilon^2/2$ 的独立高斯变量的增量；然后用 Sudakov–Fernique 不等式比较上确界，并由命题 2.1 计算独立情形。

对球面，习题 2.8 给出 $N(S^{d-1}, \|\cdot\|, 1/4) \ge 2^{d-2}$，故在 $\varepsilon = 1/4$ 处应用 Sudakov 不等式得到 $\mathbb{E}\|g\| \ge (c/4)\sqrt{(d-2)\log 2}$。结合例 2.5，

$$c'\sqrt{d} \le \mathbb{E} \sup_{u \in S^{d-1}} \langle g, u \rangle \le C\sqrt{d},$$

两侧都来自覆盖数。对并非每个 T 这些界都是尖锐的；Talagrand 的一般链化将积分替换为一个尖锐的量，但这里不需要。

习题 2.7 (A 类)**.** $[0,1]$ 上的两个过程。

(a) Brown 运动的典范度量为 $d(s,t) = \sqrt{|t-s|}$。证明 $N([0,1], d, \varepsilon) \le 1 + 1/(2\varepsilon^2)$，并由定理 2.4 推得 $\mathbb{E}\sup_{t \le 1} B_t < \infty$：连续时间上的最大值是具有有限均值的随机变量。该界为 9.7；真实值为 $\sqrt{2/\pi} \approx 0.80$。

(b) 设 $[0,1]$ 上的过程 X 满足 $\operatorname{Var} X_t \le 1$，且对某个 $L \ge 1$ 有 $d(s,t) \le L|t-s|$：它在尺度 $1/L$ 上变化。证明 $N([0,1],d,\varepsilon) \le 1 + L/(2\varepsilon)$，并推得

$$\mathbb{E} \sup_{t\in[0,1]} X_t \le 12\sqrt{\log(1+L)} + 12.$$

可使用 $A \ge 1$ 时 $\int_0^1 \sqrt{\log(A/\varepsilon)}\,d\varepsilon \le \sqrt{\log A} + 1$。将其与 L 个独立坐标的最大值 $\sqrt{2\log L}$ 比较。

(c) 网格 $\{j/n\}$ 上的并集界给出 $\mathbb{E}\max_j B_{j/n} \le \sqrt{2\log n}$，当 $n \to \infty$ 时无用，而 (a) 对 n 一致。用一句话回答：链化利用了什么被并集界丢掉的信息？

习题 2.8 (B 类)**.** 球面的下界。

(a) 设 $u_1,\dots,u_n$ 为 S^{d-1} 的 ε-网，$\varepsilon \le 1$。证明每个满足 $1-\varepsilon \le \|x\| \le 1$ 的 x 与某个 u_i 的距离不超过 2ε；比较体积得到 $n(2\varepsilon)^d \ge 1-(1-\varepsilon)^d$。

(b) 推得对 $d \ge 2$ 有 $N(S^{d-1},\|\cdot\|,1/4) \ge 2^{d-2}$。

(c) 由 Sudakov 不等式推得 $\mathbb{E}\|g\| \ge c'\sqrt{d}$，其中 c' 为绝对常数；与例 2.5 比较：$\mathbb{E}\|g\| \asymp \sqrt{d}$ 的两侧都来自球的计数。

习题 2.9 (B 类)**.** 用链化约束算子范数。设 M 为元素独立同分布于 $\mathcal{N}(0,1)$ 的 $N \times d$ 矩阵，$Y_{(u,v)} = \langle v, Mu\rangle$ 定义在 $T = S^{N-1} \times S^{d-1}$ 上，如例 1.5，故 $\sup_T Y = \|M\|_{\mathrm{op}}$。

(a) 证明典范度量为 $d((u,v),(u',v')) = \|vu^\top - v'(u')^\top\|_F$，且至多为 $\|u-u'\| + \|v-v'\|$。

(b) 证明 $N(T,d,\varepsilon) \le (1+4/\varepsilon)^{N+d}$。

(c) 推得 $\mathbb{E}\|M\|_{\mathrm{op}} \le C\sqrt{N+d} \le C(\sqrt{N}+\sqrt{d})$，其中 C 为绝对常数。Dudley 给出 $C=19$；当 $N=100$、$d=50$ 时真实值为 16.6，$\sqrt{N}+\sqrt{d} = 17.1$。第 11 讲通过比较得到常数 1。

第 10 讲指定作业，第 11 讲开始时交： 习题 2.7、2.8、2.9，共三题：对 $[0,1]$ 上的两个过程使用 Dudley 不等式；球面的下界；常数不正确的算子范数。

第 11 讲通过在两个高斯过程之间插值来比较它们，证明 Sudakov 不等式，并从比较读出高斯矩阵的算子范数。



现代机器学习中的概率

ORF 526 课程材料译稿

第 9–11 讲习题解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

解答

编号与讲义一致。[1]C 类习题的关键思路置于框中；掌握思路后其余部分是常规推导，这也正是分类的含义。[2]

第 9–11 讲：高斯过程（第 1 节）

1.10（A）

(a) $(Mu)_i = \sum_k M_{ik}u_k$，故

$$\mathbb{E}[(Mu)_i(Mv)_j] = \sum_{k,l} u_k v_l \mathbb{E}[M_{ik}M_{jl}] = \sum_{k,l} u_k v_l \delta_{ij}\delta_{kl} = \delta_{ij}\langle u, v\rangle.$$

(Mu, Mv) 是 M 的高斯元素向量的线性像，因此联合高斯（第 1–2 讲定理 1.5）；且 $\mathbb{E}\langle Mu, Mv\rangle = \sum_i \mathbb{E}[(Mu)_i(Mv)_i] = N\langle u, v\rangle$。

(b) 由 Cauchy–Schwarz，对单位向量 u 有 $\langle g, u\rangle \le \|g\|\|u\| = \|g\|$，在 $u = g/\|g\|$ 处取等号。$\mathbb{E}\|g\|^2 = \sum_i \mathbb{E}g_i^2 = d$，Jensen 不等式给出 $\mathbb{E}\|g\| \le \sqrt{\mathbb{E}\|g\|^2} = \sqrt{d}$。

(c) $\mathbb{E}\|g\|^4 = \mathbb{E}(\sum_i g_i^2)^2 = \sum_i \mathbb{E}g_i^4 + \sum_{i\neq j}\mathbb{E}g_i^2\mathbb{E}g_j^2 = 3d + d(d-1) = d^2 + 2d$。对 $\|g\|^2 = \|g\|^{2/3}\|g\|^{4/3}$ 应用指数为 3 和 3/2 的 Hölder 不等式，得到 $\mathbb{E}\|g\|^2 \le (\mathbb{E}\|g\|)^{2/3}(\mathbb{E}\|g\|^4)^{1/3}$，故

$$\mathbb{E}\|g\| \ge \frac{(\mathbb{E}\|g\|^2)^{3/2}}{(\mathbb{E}\|g\|^4)^{1/2}} = \frac{\sqrt{d}}{\sqrt{1+2/d}} \ge \sqrt{d}(1 - 1/d) \ge \sqrt{d} - 1,$$

其中用到 $(1+x)^{-1/2} \ge 1 - x/2$。$d = 100$ 时上下界为 9、10；精确值 $\sqrt{2}\,\Gamma(101/2)/\Gamma(50) = 9.975$。

1.11（A）

(a) 和：$\phi(t) = (\phi_1(t), \phi_2(t)) \in \mathbb{R}^{k_1+k_2}$ 给出 $\langle\phi(s), \phi(t)\rangle = (\Sigma_1)_{s,t} + (\Sigma_2)_{s,t}$。积：$\phi(t) = (\phi_1(t)_a\phi_2(t)_b)_{a\le k_1, b\le k_2} \in \mathbb{R}^{k_1k_2}$ 给出

$$\langle\phi(s), \phi(t)\rangle = \sum_{a,b} \phi_1(s)_a\phi_1(t)_a\phi_2(s)_b\phi_2(t)_b = (\Sigma_1)_{s,t}(\Sigma_2)_{s,t}.$$

有特征映射的核半正定（将引理 1.2 用于它所定义的过程；或直接由 $\sum_{ij} c_i c_j \Sigma_{t_i,t_j} = \|\sum_i c_i\phi(t_i)\|^2 \ge 0$）。

(b) $\langle u, v\rangle$ 是 $\mathbb{R}^d$ 上的核，其 $\phi = \mathrm{id}$；由 (a)，每个幂 $\langle u, v\rangle^m$ 也是核，其特征映射为 $u \mapsto u^{\otimes m} = (u_{a_1}\cdots u_{a_m})_{a_1,\dots,a_m} \in \mathbb{R}^{d^m}$。（$\langle u, v\rangle$ 的任何非负系数多项式，以及极限 $e^{\langle u,v\rangle}$ 也是核；后者是统计学中高斯核机器背后的核。）

---

[1]源文如此声明；本地讲义的第 2.7、2.8、2.9 题分别对应本解答的第 2.14、2.15、2.16 题，题号并不一致。另本解答引用的命题 2.3、引理 2.6、定理 2.9、例 2.11，在可得 08 讲义中分别对应独立最大值命题 2.1、球面覆盖引理 2.3、Dudley 定理 2.4、球面例 2.5。正文保留解答源的原编号，不据此推造计划第 11 讲的缺失正文。

[2]源首页如此说明，但本文件可见的 1.14（C）解答没有实际画框。

(c) $\langle u,v\rangle^2$ 的特征映射为 $\phi(u)=(u_au_b)_{a,b}=uu^\top$，为配备 Frobenius 内积的 $d\times d$ 矩阵。过程为 $X_u=\langle uu^\top,G\rangle=\sum_{a,b}u_au_bG_{ab}=u^\top Gu$，其中 G 的元素独立同分布为 $\mathcal{N}(0,1)$。检验：$\mathbb{E}[u^\top Gu\,v^\top Gv]=\sum_{a,b,c,e}u_au_bv_cv_e\delta_{ac}\delta_{be}=\langle u,v\rangle^2$。

1.12 (A)

(a) $\mathbf{1}_{[0,s]}\mathbf{1}_{[0,t]}=\mathbf{1}_{[0,\min(s,t)]}$，其积分为 $\min(s,t)$。

(b) (B_r,B_s,B_t) 是协方差由 min 给出的高斯向量，故 B_t-B_s 为高斯变量，其方差 $\Sigma_{t,t}-2\Sigma_{s,t}+\Sigma_{s,s}=t-2s+s=t-s$；当 $r\le s$ 时 $\mathrm{Cov}(B_t-B_s,B_r)=\min(t,r)-\min(s,r)=r-r=0$。由联合高斯且不相关推出独立，即第 1–2 讲定理 1.16。（由特征映射也可见：$B_t-B_s=\langle\mathbf{1}_{(s,t]},g\rangle$，且 $\mathbf{1}_{(s,t]}\perp\mathbf{1}_{[0,r]}$。）

1.13 (B)

(a) 第 1–2 讲定理 2.9 与 $\Sigma_{t,t}=t$、$\Sigma_{t,1}=t$、$\Sigma_{1,1}=1$ 给出 $\mathbb{E}[B_t\mid B_1]=tB_1$、$\mathrm{Var}(B_t\mid B_1)=t-t^2=t(1-t)$。故 $B_t=tB_1+(B_t-tB_1)$，其中桥 B_t-tB_1 独立于 B_1，是方差 $t(1-t)$ 的高斯变量：两端为零，中间最大。

(b) 令 $t\in[t_j,t_{j+1}]$（$t_0=0,B_0=0$），线性插值为 $L_t=B_{t_j}+\frac{t-t_j}{t_{j+1}-t_j}(B_{t_{j+1}}-B_{t_j})$。由第 1–2 讲定理 2.9，条件均值是使 $B_t-\sum_i a_iB_{t_i}$ 与每个 B_{t_k} 不相关的唯一线性组合；L_t 是这样的组合，只须验证协方差为零。令 $\theta=(t-t_j)/(t_{j+1}-t_j)$，则

$$B_t-L_t=(1-\theta)(B_t-B_{t_j})-\theta(B_{t_{j+1}}-B_t).$$

对 $k\le j$，由习题 1.12(b)，两个增量都独立于 B_{t_k}；对 $k\ge j+1$，其与 B_{t_k} 的协方差分别为 $t-t_j$ 和 $t_{j+1}-t$，故由 θ 的选取，总协方差为 $(1-\theta)(t-t_j)-\theta(t_{j+1}-t)=0$。（$t>t_n$ 时没有右端点，类似计算给出 $\mathbb{E}[B_t\mid\cdots]=B_{t_n}$。）由 (a) 缩放得条件方差为 $\theta(1-\theta)(t_{j+1}-t_j)$，因此给定 n 个点的布朗运动后验是一串独立桥，正是直观图像。

译注：若最后观测时刻 $t_n<1$，桥的描述仅用于相邻已观测时刻之间；$[t_n,1]$ 上残差 $B_t-B_{t_n}$ 是独立 Brown 运动尾段，没有被右端点固定成桥。前面的条件均值 B_{t_n} 正确。

1.14 (C)

(a) 对每个 g，$\sup_t X_t=\sup_t\langle\phi(t),g\rangle=\sup_{h\in S}\langle h,g\rangle$：两个上确界遍历同一数集。取期望即可。

(b) 对固定 $h_0\in S$，$\sup_{h\in S}\langle h,g\rangle\ge\langle h_0,g\rangle$，后者期望为零；关于 S 的单调性来自上确界的单调性。$\langle h+x,g\rangle=\langle h,g\rangle+\langle x,g\rangle$ 且 $\mathbb{E}\langle x,g\rangle=0$，而 $\langle\lambda h,g\rangle=\lambda\langle h,g\rangle$。线性函数在凸包上的上确界在集合点上达到：若 $h=\sum_j\theta_jh_j$、$\theta_j\ge0$、$\sum_j\theta_j=1$，则 $\langle h,g\rangle=\sum_j\theta_j\langle h_j,g\rangle\le\max_j\langle h_j,g\rangle$，故 $w(\mathrm{conv}\,S)\le w(S)$，反向不等式来自单调性。[3]

[3]原文用“达到”；一般集合的上确界未必取到，但此处不等式论证仍给出上确界相等。

(c) $\langle h,g\rangle$ 在单位球上的上确界是对偶范数：

$$\sup_{\|h\|_2\le 1}\langle h,g\rangle=\|g\|_2,\qquad \sup_{\|h\|_1\le 1}\langle h,g\rangle=\max_i|g_i|,\qquad \sup_{\|h\|_\infty\le 1}\langle h,g\rangle=\|g\|_1.$$

分别在 $h=g/\|g\|$、$h=\pm e_i$、$h=\operatorname{sign}(g)$ 处取到。于是 $\sqrt{k}-1\le\mathbb{E}\|g\|_2\le\sqrt{k}$ 来自习题 1.10(c)。$\max_i|g_i|=\max_{j\le 2k}Y_j$，其中 $Y=(g_1,\dots,g_k,-g_1,\dots,-g_k)$ 的 $2k$ 个分量均标准高斯、彼此依赖，而命题 1.9 不要求独立：上界为 $\sqrt{2\log(2k)}$。又 $\mathbb{E}\|g\|_1=k\mathbb{E}|g_1|=k\sqrt{2/\pi}$，因为 $\mathbb{E}|g_1|=(2/\sqrt{2\pi})\int_0^\infty xe^{-x^2/2}dx=\sqrt{2/\pi}$。

(d) 若 $h\in S_k$ 的支撑为 I、$|I|\le k$，在 I 上用 Cauchy–Schwarz：$\langle h,g\rangle\le\|h\|_2(\sum_{i\in I}g_i^2)^{1/2}\le(\sum_{i\in I}g_i^2)^{1/2}$，当 h 正比于 $(g_i)_{i\in I}$ 时取等号。对 I 最大化即选 k 个最大的 $|g_i|$，所以

$$\sup_{h\in S_k}\langle h,g\rangle=\left(\sum_{i\le k}|g|_{(i)}^2\right)^{1/2}\le\sqrt{k}\max_i|g_i|,$$

其中 $|g|_{(1)}\ge|g|_{(2)}\ge\cdots$ 为 $|g_i|$ 的次序统计量。由 (c)，$w(S_k)\le\sqrt{k}\sqrt{2\log(2d)}$。与 $w(B_2^d)\ge\sqrt{d}-1$ 相比，稀疏集的宽度为 $\sqrt{k\log d}$ 量级，仿佛它位于 $k\log d$ 维中。恢复 k-稀疏向量所需高斯测量次数在常数意义下为宽度的平方，即 $k\log d$ 而非 d；这正是更精细界 $w(S_k)\le\sqrt{2k\log(ed/k)}$ 与 Gordon 逃逸定理的内容。

译注：$\sqrt{k\log d}$ 和 $k\log d$ 是稀疏区域的粗略尺度 / 上界说法，不能对所有 $1\le k\le d$ 一致视为等阶。例如 $k=d$ 时整个球面的宽度为 $\Theta(\sqrt{d})$，不是 $\Theta(\sqrt{d\log d})$。一般 k 的适当几何尺度涉及 $k\log(ed/k)$；恢复结论还需要相应恢复模型和定理假设，此处不补证。

1.15 (B)

(a) $\operatorname{Cov}(X_i,X_j)=\rho+(1-\rho)\delta_{ij}$：方差均为 1，相关系数均为 ρ。由于 g_0 不依赖 i，$\max_i X_i=\sqrt{\rho}\,g_0+\sqrt{1-\rho}\max_i g_i$，而 $\mathbb{E}g_0=0$，故 $\mathbb{E}\max_i X_i=\sqrt{1-\rho}\,\mathbb{E}\max_i g_i\approx\sqrt{(1-\rho)2\log n}$。并集界 $\sqrt{2\log n}$ 仅在 $\rho=0$ 时达到；$\rho=1$ 时所有 X_i 相同，其最大值是单个均值为零的 $\mathcal{N}(0,1)$ 变量。

(b) 并集界（命题 1.9，$\operatorname{Var}X_i=\|u_i\|^2=1$）给出 $\sqrt{2\log n}$。另一方面，逐点有 $\max_i\langle u_i,g\rangle\le\sup_{\|u\|=1}\langle u,g\rangle=\|g\|$，故 $\mathbb{E}\max_i X_i\le\mathbb{E}\|g\|\le\sqrt{d}$（习题 1.10）。当 $n\le d$ 且 u_i 正交归一时，第一界是尖锐的：此时 X_i 独立同分布为标准高斯，命题 2.3 给出 $\sqrt{2\log n}(1+o(1))$。当 u_i 遍布整个球面时第二界尖锐：若每个单位向量距某个 u_i 不超过 ϵ，则最大化向量 $u^*=g/\|g\|$ 有 $\|u_i-u^*\|\le\epsilon$，故 $\max_i X_i\ge(1-\epsilon)\|g\|$、$\mathbb{E}\max_i X_i\ge(1-\epsilon)\mathbb{E}\|g\|$。第 10 讲计数所需点数为 $e^{\Theta(d)}$，正是两界交叉之处。

1.16 (B)

(a) $X_t=\langle\phi(t),g\rangle=0$ 当且仅当 $\phi(t)\perp g$，即 $\phi(t)\in g^\perp$；由于 $g\neq 0$ 几乎处处成立，$g^\perp$ 是经过原点的超平面。对旋转 U，由第 1–2 讲定理 1.5，$Ug\sim\mathcal{N}(0,UU^\top)=\mathcal{N}(0,I_k)$，且 $(Ug)^\perp=U(g^\perp)$，故 $U(g^\perp)$ 与 $g^\perp$ 同分布。等价地，单位法向量 $g/\|g\|$ 在 S^{k-1} 上均匀。

(b) 由 (a)，$\#\{t : X_t = 0\}$ 是曲线 ϕ 与随机超平面 $g^\perp$ 相交的次数；这也等于其投影 γ 的交点数，因为 $\phi(t) \in g^\perp$ 当且仅当 $\gamma(t) \in g^\perp$。令 $f(A)$ 为球面上曲线 A 的期望交点数。将曲线截成几段时它可加（随机超平面以概率 1 避开任意给定有限点集），由 (a) 它也旋转不变。长度为 ℓ 的所有大圆弧互为旋转，故其 f 仅是长度的函数 $F(\ell)$；该函数可加且非减，因此 $F(\ell) = c\ell$。长为 2π 的完整大圆 C 是某二维平面 P 的单位圆；$g^\perp$ 与 P 相交于过原点的直线（它以概率 1 不包含 P），直线恰与圆交于两点。故 $2 = F(2\pi) = 2\pi c$，即 $c = 1/\pi$。对光滑 γ 内接大圆多边形：其长度趋于 $\mathrm{length}(\gamma)$，交点数趋于 γ 的交点数，从而 $\mathbb{E}\# = \mathrm{length}(\gamma)/\pi$。这是 Crofton 公式；在平面中同一论证就是 Buffon 投针。

(c) $X_\theta = \langle \phi(\theta), g\rangle$，其中 $\phi(\theta) = (\cos\theta, \sin\theta, \cos 2\theta, \sin 2\theta, \dots, \cos n\theta, \sin n\theta) \in \mathbb{R}^{2n}$，$g = (a_1, b_1, \dots, a_n, b_n)$。因此

$$\|\phi(\theta)\|^2 = \sum_{j\le n}(\cos^2 j\theta + \sin^2 j\theta) = n, \quad \|\gamma'(\theta)\|^2 = \frac{1}{n}\sum_{j\le n} j^2 = \frac{(n+1)(2n+1)}{6},$$

其中 $\gamma = \phi/\sqrt{n}$。由 (b)，

$$\mathbb{E}\#\{\theta \in [0, 2\pi) : X_\theta = 0\} = \frac{1}{\pi}\cdot 2\pi\sqrt{\frac{(n+1)(2n+1)}{6}} = 2\sqrt{\frac{(n+1)(2n+1)}{6}} \sim \frac{2n}{\sqrt{3}}.$$

特征曲线以恒定速度绕行 $\mathbb{R}^{2n}$ 中半径 $\sqrt{n}$ 的球面，随机超平面切它约 $2n/\sqrt{3}$ 次：每单位频率略多于 $n = 1$ 的大圆的两次交点，因为高次谐波使曲线更长。[4]（比较而言，独立同分布高斯系数的 n 次随机代数多项式只有约 $(2/\pi)\log n$ 个实零点：其特征曲线 $(1, x, \dots, x^n)$ 投到球面后很短。）

上确界（第 2 节）

2.14 (A)

(a) 令 $t_j = \min\{(2j-1)\epsilon^2, 1\}$，$j = 1, \dots, \lceil 1/(2\epsilon^2)\rceil$。每个 $t \in [0,1]$ 都在某个 t_j 的 $|\cdot|$ 距离 ϵ^2 以内，因此在 $d = \sqrt{|\cdot|}$ 距离 ϵ 以内，故 $N([0,1], d, \epsilon) \le \lceil 1/(2\epsilon^2)\rceil \le 1 + 1/(2\epsilon^2)$。直径为 1，定理 2.9 给出

$$\mathbb{E}\sup_{t\le 1} B_t \le 12\int_0^{1/2}\sqrt{\log(1 + 1/(2\epsilon^2))}\,d\epsilon = 12 \times 0.806 = 9.68 < \infty.$$

精确值 $\sqrt{2/\pi}$ 来自反射原理 $\sup_{t\le 1} B_t \overset{d}{=} |B_1|$，这是关于路径、超出本课程的陈述。

译注： 这里使用 Brown 运动的连续 / 可分版本，其路径最大值与前述有限子集定义一致。仅具有相同高斯有限维分布的任意版本未必有同样上确界；例如 $X_t = \mathbf{1}_{\{t=U\}}$（$U$ 在 $[0,1]$ 均匀）各有限边缘均为零而路径上确界为 1。典范距离也可能只是伪度量。

(b) 点 $t_j = \min\{(2j-1)\epsilon/L, 1\}$，$j \le \lceil L/(2\epsilon)\rceil$，距每个 t 不超过 ϵ/L，故在 d 中不超过 ϵ，所以 $N \le 1 + L/(2\epsilon)$。又 $d(s,t) \le \sqrt{\mathrm{Var}\, X_s} + \sqrt{\mathrm{Var}\, X_t} \le 2$，故定理 2.9 的积分范围至多为 $[0,1]$。当 $\epsilon \le 1$，$1 + L/(2\epsilon) \le (1+L)/\epsilon$，以 $A = 1 + L$ 代入给定估计得

$$\mathbb{E}\sup X_t \le 12\big(\sqrt{\log(1+L)} + 1\big).$$

[4] 按前面的渐近式，每单位频率的系数为 $2/\sqrt{3} < 2$，与此处“略多于”不一致；保留原文以待核。

所用估计为 $\sqrt{\log(A/\epsilon)} \le \sqrt{\log A}+\sqrt{\log(1/\epsilon)}$ 和 $\int_0^1 \sqrt{\log(1/\epsilon)}\,d\epsilon = \Gamma(3/2) < 1$。$\sqrt{\log L}$ 的量级与 L 个独立标准高斯变量的最大值相同：在尺度 $1/L$ 上变化的过程在 $[0,1]$ 中约有 L 个真正不同的值。检验：核 $\Sigma_{s,t} = e^{-L^2(s-t)^2/2}$ 有 $d(s,t)^2 = 2(1-e^{-L^2(s-t)^2/2}) \le L^2(s-t)^2$；$L=50$ 时一次模拟给出 $\mathbb{E}\sup = 2.27$，与 $\sqrt{2\log L} = 2.80$ 和上界 34 相比。

(c) 邻近点的值几乎相同：并集界把 $B_{j/n}$ 与 $B_{(j+1)/n}$ 当成两个无关高斯变量；而链式法估计它们的差，其标准差 $1/\sqrt{n}$ 很小，并只在这一小尺度上支付 $\sqrt{\log(\text{链数})}$。

2.15 (B)

(a) 设 $1-\epsilon \le \|x\| \le 1$，则 $x \neq 0$[5]，令 $u = x/\|x\| \in S^{d-1}$。存在 u_i 满足 $\|u-u_i\| \le \epsilon$，且 $\|x-u\| = 1-\|x\| \le \epsilon$，故 $\|x-u_i\| \le 2\epsilon$。因此 n 个球 $B(u_i, 2\epsilon)$ 覆盖壳层 $\{1-\epsilon \le \|x\| \le 1\}$，其体积为 $(1-(1-\epsilon)^d)\,\mathrm{vol}(B_2^d)$，而这些球的总体积为 $n(2\epsilon)^d\,\mathrm{vol}(B_2^d)$。故 $n(2\epsilon)^d \ge 1-(1-\epsilon)^d$。

(b) $\epsilon = 1/4$ 时，对 $d \ge 2$，

$$n \ge 2^d(1-(3/4)^d) \ge 2^d(1-9/16) = \frac{7}{16}2^d \ge 2^{d-2}.$$

结合引理 2.6，$2^{d-2} \le N(S^{d-1}, \|\cdot\|, 1/4) \le 9^d$：固定尺度下球面的覆盖数为 $e^{\Theta(d)}$。

(c) 在 $\epsilon = 1/4$ 对 (b) 应用 Sudakov 不等式，

$$\mathbb{E}\|g\| = \mathbb{E}\sup_u \langle g, u\rangle \ge c\cdot\frac{1}{4}\sqrt{\log 2^{d-2}} = \frac{c}{4}\sqrt{(d-2)\log 2},$$

例如 $d \ge 4$ 时这是 $c'\sqrt{d}$。例 2.11 从上界 $N \le (1+2/\epsilon)^d$ 得到 $\mathbb{E}\|g\| \le 12c_0\sqrt{d}$。因此仅由固定尺度的 $N(S^{d-1}, \|\cdot\|, \epsilon) = e^{\Theta(d)}$ 就得到 $\mathbb{E}\|g\| \asymp \sqrt{d}$。（习题 1.10 当然直接给出尖锐区间 $[\sqrt{d}-1, \sqrt{d}]$；要点是覆盖数本身已包含该量级。）

2.16 (B)

(a) $Y_{(u,v)} = \sum_{ij} v_i u_j M_{ij} = \langle vu^\top, M\rangle_F$ 是 M 元素的线性函数。对固定矩阵 A，$\mathrm{Var}\langle A, M\rangle_F = \sum_{ij} A_{ij}^2 = \|A\|_F^2$，故

$$\begin{aligned} d((u,v),(u',v'))^2 &= \mathrm{Var}\langle vu^\top - v'(u')^\top, M\rangle_F \\ &= \|vu^\top - v'(u')^\top\|_F^2 = 2 - 2\langle v, v'\rangle\langle u, u'\rangle. \end{aligned}$$

展开时用到 $\|ab^\top\|_F = \|a\|\|b\|$ 和 $\langle ab^\top, cd^\top\rangle_F = \langle a,c\rangle\langle b,d\rangle$。为得三角界，写 $vu^\top - v'(u')^\top = v(u-u')^\top + (v-v')(u')^\top$，故 $d \le \|v\|\|u-u'\| + \|v-v'\|\|u'\| = \|u-u'\| + \|v-v'\|$。

(b) 令 U, V 分别为 S^{d-1}、S^{N-1} 的 $\epsilon/2$-网，其大小如引理 2.6。对 $(u,v) \in T$，取 $u' \in U, v' \in V$ 分别在 u, v 的 $\epsilon/2$ 邻域内；由 (a)，$d((u,v),(u',v')) \le \epsilon$。故 $U \times V$ 是 ϵ-网，大小至多 $(1+4/\epsilon)^d(1+4/\epsilon)^N$。且 $D \le \|vu^\top\|_F + \|v'(u')^\top\|_F = 2$。定理 2.9 给出

$$\mathbb{E}\|M\|_{\mathrm{op}} = \mathbb{E}\sup_T Y \le 12\int_0^1 \sqrt{(N+d)\log(1+4/\epsilon)}\,d\epsilon = 12c_1\sqrt{N+d}, \quad c_1 = 1.559,$$

其中 $12c_1 = 18.7 \le 19$，且 $\sqrt{N+d} \le \sqrt{N}+\sqrt{d}$。$N=100, d=50$ 时界为 229，而真实值为 16.6。

[5]这一推断需要 $\epsilon < 1$；此处保留原文，后续应用取 $\epsilon = 1/4$。

(c) 由 (a) 和 $|\langle v, v'\rangle| \le 1$,

$$d^2 \ge 2 - 2|\langle u, u'\rangle| = \min\{\|u - u'\|^2, \|u + u'\|^2\}.$$

固定任意 $u \in S^{d-1}$ 和 v; 某个网点 (u_i, v_i) 距 (u, v) 不超过 ϵ, 故 u 距 u_i 或 $-u_i$ 不超过 ϵ。于是 $2n$ 个点 $\pm u_i$ 构成 S^{d-1} 的 ϵ-网, $2n \ge N(S^{d-1}, \epsilon)$; 对称地 $2n \ge N(S^{N-1}, \epsilon)$。在 $\epsilon = 1/4$, 习题 2.15(b) 给出 $n \ge \frac{1}{2} 2^{\max(N,d)-2} = 2^{\max(N,d)-3}$。

(d) $\epsilon = 1/4$ 时由 Sudakov 不等式,

$$\mathbb{E}\|M\|_{\mathrm{op}} \ge \frac{c}{4}\sqrt{(\max(N, d) - 3)\log 2} \ge c'\sqrt{\max(N, d)} \ge \frac{c'}{2}(\sqrt{N} + \sqrt{d})$$

例如对 $\max(N, d) \ge 6$ 成立 (其余情形由 $\mathbb{E}\|M\|_{\mathrm{op}} \ge \mathbb{E}|M_{11}| > 0$ 覆盖)。与 (b) 合并,

$$c''(\sqrt{N} + \sqrt{d}) \le \mathbb{E}\|M\|_{\mathrm{op}} \le 19(\sqrt{N} + \sqrt{d}) :$$

仅由 $S^{N-1} \times S^{d-1}$ 的覆盖数得到高斯矩阵算子范数的量级。第 11 讲通过比较将上界常数改进为 1。



现代机器学习中的概率

ORF 526 课程材料译稿

模拟期中考试解答（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

模拟期中考试——解答

译注：本地仅取得解答，未取得原题单。以下推导所需的中心联合高斯、Σ_{YY} 可逆，以及中心化、逐行独立且方差和归一的三角阵列等设定，是本解答使用的前提，不是从解答结论证明出的事实。岭比值还需 $\tau \neq 0$；不能据此声称已恢复原题。

问题 1：作为投影的条件化

(a) 若 $\mathbb{R}^d$ 中随机向量 X 的特征函数是高斯特征函数，则称其为均值 μ、协方差 Σ 的高斯向量：

$$\mathbb{E}e^{-i\langle X,\xi\rangle} = \exp\left(-i\langle \mu,\xi\rangle - \tfrac{1}{2}\xi^{\top}\Sigma\xi\right) \quad \text{对每个}\xi \in \mathbb{R}^d,$$

其中 $\mu \in \mathbb{R}^d$，Σ 对称且半正定。这样定义而不通过密度定义的要点是：Σ 奇异时它仍有意义；这正是 (c) 中可能发生的情形，向量 $(X - AY, Y)$ 可能退化。

(b) 定理有两个结论：$X - AY$ 独立于 Y，且 $\mathbb{E}[X \mid Y] = AY$。第一个是实质内容；第二个可由它一行推出。

(c) 整个证明是一次协方差计算，加上允许引用的事实。

首先 $(X - AY, Y)$ 是 (X, Y) 的线性像——乘以 $\begin{pmatrix} I & -A \\ 0 & I \end{pmatrix}$——故它仍是中心高斯向量。这使得我们可以通过协方差讨论独立性。现在计算互协方差：

$$\mathrm{Cov}(X - AY, Y) = \Sigma_{XY} - A\Sigma_{YY} = \Sigma_{XY} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YY} = 0.$$

这当然正是选择 A 的方式：它是使互协方差为零的唯一矩阵。联合高斯且不相关意味着独立，所以 $X - AY$ 独立于 Y。

为求条件期望，写 $X = (X - AY) + AY$。第二项是 Y 的函数，给定 Y 条件化时不变；第一项独立于 Y，条件化后保持其普通期望，即 0。因此 $\mathbb{E}[X \mid Y] = 0 + AY$。

几何上，AY 是 X 在 Y 所张成空间上的正交投影（L^2 意义下），$X - AY$ 是残差。对一般随机变量，残差仅与 Y 不相关；对高斯变量它独立。这是高斯假设被使用的唯一位置，且恰好用了一次。

(d) 信号加噪声就是 $X = w$、$Y = y$ 的情形。(w, y) 是 (w, ξ) 的线性像，故为中心高斯向量，所需的三个块为

$$\Sigma_{ww} = \tau^2 I, \qquad \Sigma_{wy} = \mathrm{Cov}(w, w + \sigma\xi) = \tau^2 I, \qquad \Sigma_{yy} = \tau^2 I + \sigma^2 I.$$

（互协方差块是 $\tau^2 I$，不是 $(\tau^2 + \sigma^2)I$：噪声与 w 独立，对 $\mathrm{Cov}(w, y)$ 无贡献。）于是 $A = \Sigma_{wy}\Sigma_{yy}^{-1} = \frac{\tau^2}{\tau^2+\sigma^2} I$，定理给出

$$\mathbb{E}[w \mid y] = \frac{\tau^2}{\tau^2 + \sigma^2} y, \qquad \mathrm{Cov}(w \mid y) = \tau^2 I - \frac{\tau^4}{\tau^2 + \sigma^2} I = \frac{\tau^2\sigma^2}{\tau^2 + \sigma^2} I.$$

因此后验均值是向 0 收缩 $\tau^2/(\tau^2 + \sigma^2)$ 倍的观测值，而后验协方差为不依赖实际观测的标量。这是最简单形式的岭回归：$H = I$、$\lambda = \sigma^2/\tau^2$。

问题 2：Lindeberg 定理

这是独立同分布中心极限定理的替换论证，只作一处改变：未假设三阶矩存在，因此求和项较大时必须将三次余项界替换为二次界。Lindeberg 条件恰好说明大项无关紧要。

*没有单项重要。*首先，Lindeberg 条件迫使每个单项方差都小。在 ϵ 处拆分 $Y_{n,i}$ 的二阶矩：

$$\sigma_{n,i}^2 = \mathbb{E}[Y_{n,i}^2 \mathbf{1}_{\{|Y_{n,i}|\le\epsilon\}}] + \mathbb{E}[Y_{n,i}^2 \mathbf{1}_{\{|Y_{n,i}|>\epsilon\}}] \le \epsilon^2 + L_n(\epsilon).$$

右侧不依赖 i，因此先令 $n\to\infty$、再令 $\epsilon\to 0$，得 $\max_i \sigma_{n,i}\to 0$。最后处理高斯一侧时需要这一点。

*替换。*固定测试函数 $f\in C^3$，且 f''、f''' 有界。令 $g_{n,i}\sim\mathcal{N}(0,\sigma_{n,i}^2)$ 彼此独立，也独立于数组。方差和为 1，故它们的和服从 $\mathcal{N}(0,1)$，即 $\mathbb{E}f(g)=\mathbb{E}f(\sum_i g_{n,i})$：将 T_n 与具有相同方差轮廓的高斯和逐项比较，每次把一个 Y 替换为 g。记除第 i 个位置外的和为

$$W_{n,i} = g_{n,1}+\cdots+g_{n,i-1}+Y_{n,i+1}+\cdots+Y_{n,k_n}.$$

替换 $i-1$ 次后的和为 $W_{n,i}+Y_{n,i}$，替换 i 次后为 $W_{n,i}+g_{n,i}$。望远镜求和得

$$|\mathbb{E}f(T_n)-\mathbb{E}f(g)| \le \sum_{i=1}^{k_n} |\mathbb{E}f(W_{n,i}+Y_{n,i}) - \mathbb{E}f(W_{n,i}+g_{n,i})|.$$

关键是 $W_{n,i}$ 与 $Y_{n,i}$、$g_{n,i}$ 都独立。围绕 $W_{n,i}$ 对两边 Taylor 展开，常数项相同；线性项由独立性分解为均值乘另一因子，而两个均值均为 0。原文称二次项两侧均分解为 $\sigma_{n,i}^2\mathbb{E}f''(W_{n,i})$，因为方差相同。[1]所以除余项外全部抵消：

$$|\mathbb{E}f(W_{n,i}+Y_{n,i}) - \mathbb{E}f(W_{n,i}+g_{n,i})| \le \mathbb{E}|R(Y_{n,i})| + \mathbb{E}|R(g_{n,i})|.$$

*余项。*这是与独立同分布情形不同的一步。Y 一侧未假设三阶矩，故只在 $|Y_{n,i}|\le\epsilon$ 时使用三次界，此时 $|Y|^3\le\epsilon Y^2$；在 $|Y_{n,i}|>\epsilon$ 时使用二次界：

$$\begin{aligned}\sum_i \mathbb{E}|R(Y_{n,i})| &\le \frac{\|f'''\|_\infty}{6}\epsilon\sum_i \mathbb{E}Y_{n,i}^2 + \|f''\|_\infty \sum_i \mathbb{E}[Y_{n,i}^2\mathbf{1}_{\{|Y_{n,i}|>\epsilon\}}]\\ &= \frac{\|f'''\|_\infty}{6}\epsilon + \|f''\|_\infty L_n(\epsilon).\end{aligned}$$

高斯一侧无需截断，始终使用三次界：$\mathbb{E}|g_{n,i}|^3=\sigma_{n,i}^3\mathbb{E}|g|^3$，且 $\sum_i\sigma_{n,i}^3\le\max_i\sigma_{n,i}\sum_i\sigma_{n,i}^2=\max_i\sigma_{n,i}$，故

$$\sum_i \mathbb{E}|R(g_{n,i})| \le \frac{\|f'''\|_\infty \mathbb{E}|g|^3}{6}\max_i\sigma_{n,i},$$

这正是需要第一步的地方。

*结论。*合起来，

$$|\mathbb{E}f(T_n)-\mathbb{E}f(g)| \le \frac{\|f'''\|_\infty}{6}\epsilon + \|f''\|_\infty L_n(\epsilon) + \frac{\|f'''\|_\infty\mathbb{E}|g|^3}{6}\max_i\sigma_{n,i}.$$

令 $n\to\infty$：第二项由 Lindeberg 条件趋零，第三项由第一步趋零，留下 $\limsup_n|\mathbb{E}f(T_n)-\mathbb{E}f(g)|\le\|f'''\|_\infty\epsilon/6$。$\epsilon$ 任意，故极限为零。该结论对每个光滑测试函数成立，再由归约引理推广为依分布收敛。

[1]按 Taylor 展开，二次项还应有共同因子 $1/2$；原文未写出该因子，不影响两侧抵消。

问题 3：高斯向量的范数

(a) (i) (T,d) 的 ϵ-网是子集 $T'\subset T$，使得 T 的每一点距 T' 中某点不超过 ϵ。覆盖数 $N(T,d,\epsilon)$ 是 ϵ-网的最小大小；若不存在有限网则为 $+\infty$。

(ii) 对中心高斯过程 $(X_t)_{t\in T}$，典范度量是坐标之间的 L^2 距离，

$$d(s,t)=\big(\mathbb{E}(X_s-X_t)^2\big)^{1/2}=\sqrt{\Sigma_{s,s}-2\Sigma_{s,t}+\Sigma_{t,t}},$$

其中 $\Sigma_{s,t}=\mathbb{E}[X_sX_t]$ 为协方差核。过程通过这一度量“看到”其指标集。

(b) 任何有限集合 $(\langle g,u_1\rangle,\dots,\langle g,u_n\rangle)$ 均是 g 的线性像，故是中心高斯向量：X 是中心高斯过程。其上确界显式可得，这使它成为好的检验例子：由 Cauchy–Schwarz，对每个单位 u 有 $\langle g,u\rangle\le\|g\|$，且 $u=g/\|g\|$ 时取等号，故 $\sup_u X_u=\|g\|$。典范度量同样显式：$X_u-X_v=\langle g,u-v\rangle$ 是方差 $\|u-v\|^2$ 的高斯变量，故 $d(u,v)=\|u-v\|$，即欧氏度量；直径 $D=2$，在对跖点取到。

所以“$\mathbb{E}\|g\|$ 有多大”等价于“以球面为指标的高斯过程最大值有多大”，两个定理仅根据球面几何便回答了它。

(c) Dudley 积分的上限为 $D/2=1$。代入给定覆盖界，

$$\begin{aligned}\mathbb{E}\|g\|&\le 12\int_0^1\sqrt{\log N(S^{d-1},\|\cdot\|,\epsilon)}\,d\epsilon\\&\le 12\int_0^1\sqrt{d\log(1+2/\epsilon)}\,d\epsilon=C\sqrt{d},\end{aligned}$$

其中 $C=12\int_0^1\sqrt{\log(1+2/\epsilon)}\,d\epsilon$。维数从平方根中提出，剩下的积分是常数（约 1.35，因此 $C\approx 16$）。

(d) Sudakov 不等式在每个尺度成立，取一个尺度已足够。$\epsilon=1/4$ 时给定下界为 $\log N\ge(d-2)\log 2$，所以对 $d\ge 4$，

$$\mathbb{E}\|g\|\ge c\cdot\frac{1}{4}\sqrt{(d-2)\log 2}\ge c'\sqrt{d},$$

其中用了 $d-2\ge d/2$。结合 (c) 得 $c'\sqrt{d}\le\mathbb{E}\|g\|\le C\sqrt{d}$。$d$ 维球面上有指数多个充分分离的点，这是两个定理所用的唯一球面性质。

常数远非尖锐：由 $\|g\|$ 的二阶和四阶矩可得到真实的界 $\sqrt{d}-1\le\mathbb{E}\|g\|\le\sqrt{d}$；但 $\sqrt{d}$ 的量级正确，而且推导它不需要计算任何矩。



现代机器学习中的概率

ORF 526 课程材料译稿

第 12–15 讲：鞅（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

1 回顾：L^2、投影与条件期望

第 12–15 讲：鞅

条件期望 · 停时与收敛 · 鞅中心极限定理 · 集中性

阅读指南。第 1 节回顾 L^2 和正交投影，并定义条件期望。第 1–2 节是第 12 讲，第 3 节是第 13 讲，第 4 节是第 14 讲，第 5 节是第 15 讲。所有内容均在 L^2 中进行。来自课程外的事实放在标记为“引用”的方框中。标记为“课堂演算”的例子将在黑板上完成。习题分 A 类（常规）、B 类（演算例子或短证明）和 C 类（较长；鼓励使用 AI 辅助）；一讲的家庭作业是其结尾的习题组。

译注： 原文“所有内容均在 L^2”需作范围补充。$X \in L^2$ 的平方、残差平方一般仅在 L^1，可积三次余项也未必在 L^2。下文条件方差、平方鞅 / 次鞅、最大不等式的平方过程及条件 Taylor 余项，须使用条件期望对 L^1 的标准延拓（由可积性和对有界条件检验函数的积分恒等式刻画），不能仅诉诸已写的 L^2 正交投影。平方过程是可积鞅 / 次鞅，未必为原定义的 L^2 鞅；若坚持后者就需相应四阶或更高矩。各 L^2 收敛 / 正交结论仍使用其明确二阶矩条件。

1.1 L^2 与正交投影

L^2 是满足 $\mathbb{E}X^2 < \infty$ 的实随机变量 X 所组成的空间，内积和范数为

$$\langle X, Z\rangle = \mathbb{E}[XZ], \qquad \|X\|_2 = (\mathbb{E}X^2)^{1/2}.$$

对有限随机变量族 $Y = (Y_1, \dots, Y_n)$（取值于某个 $\mathbb{R}^m$），令

$$L^2(Y) = \{f(Y) : f : \mathbb{R}^m \to \mathbb{R},\ \mathbb{E}f(Y)^2 < \infty\},$$

即 Y 的具有有限二阶矩的函数。它是 L^2 的线性子空间，包含常数；对任意其他随机变量族 Y'，都有 $L^2(Y) \subset L^2(Y, Y')$。

引用 · Hilbert 空间

L^2 完备：在 $\|\cdot\|_2$ 下为 Cauchy 的序列在该范数下收敛。每个 $L^2(Y)$ 均为闭子空间。对闭子空间 $V \subset L^2$ 和 $X \in L^2$，存在唯一的 $P_V X \in V$ 使 $\|X - P_V X\|_2 = \min_{W \in V} \|X - W\|_2$，其特征为对所有 $W \in V$，$\langle X - P_V X, W\rangle = 0$。映射 P_V 线性，且 $\|P_V X\|_2 \le \|X\|_2$；$\|X\|_2^2 = \|P_V X\|_2^2 + \|X - P_V X\|_2^2$；若 $V \subset W$ 为闭子空间，则 $P_V P_W = P_W P_V = P_V$。

1.2 条件期望

定义 1.1 (条件期望)**.** 对 $X \in L^2$ 和有限随机变量族 Y，定义 $\mathbb{E}[X \mid Y] := P_{L^2(Y)} X$，即 X 到 $L^2(Y)$ 的正交投影。

这是第 1–2 讲的定义：$\mathbb{E}[X \mid Y]$ 在所有满足 $f(Y) \in L^2$ 的函数 f 中使 $\mathbb{E}(X - f(Y))^2$ 最小，即通过任意 Y 的函数对 X 作最佳均方预测。最佳线性预测则是到较小子空间 $\operatorname{span}(1, Y_1, \dots, Y_n)$ 的投影；两者一般不同（例 1.7），对高斯向量则相同（定理 1.6）。

引理 1.2 (刻画)**.** 设 $Z \in L^2(Y)$。则 $Z = \mathbb{E}[X \mid Y]$ 当且仅当对每个 $f(Y) \in L^2(Y)$ 都有 $\mathbb{E}[(X-Z)f(Y)] = 0$；只检验有界 f 就足够。

证明. 第一条即方框中的刻画。对于第二条，作截断：$f_M = \max(-M, \min(f, M))$ 满足 $f_M(Y) \to f(Y)$ 于 L^2 中，且由 Cauchy–Schwarz，$\mathbb{E}[(X-Z)f_M(Y)] \to \mathbb{E}[(X-Z)f(Y)]$。 □

命题 1.3 (规则)**.** 设 $X, X' \in L^2$，$a, b \in \mathbb{R}$，Y, Y' 为有限随机变量族。

(i) 线性：$\mathbb{E}[aX + bX' \mid Y] = a\mathbb{E}[X \mid Y] + b\mathbb{E}[X' \mid Y]$。

(ii) 取平均：$\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}X$。

(iii) 提出已知量：若 $g(Y) \in L^2(Y)$ 且 $g(Y)X \in L^2$，则 $g(Y)\mathbb{E}[X \mid Y] \in L^2$，且 $\mathbb{E}[g(Y)X \mid Y] = g(Y)\mathbb{E}[X \mid Y]$；特别地，$\mathbb{E}[g(Y) \mid Y] = g(Y)$。

(iv) 塔式性质：$\mathbb{E}[\mathbb{E}[X \mid Y, Y'] \mid Y] = \mathbb{E}[X \mid Y] = \mathbb{E}[\mathbb{E}[X \mid Y] \mid Y, Y']$。

(v) 独立性：若 X 与 Y 独立，则 $\mathbb{E}[X \mid Y] = \mathbb{E}X$。

(vi) 非负性：若 $X \geq 0$，则 $\mathbb{E}[X \mid Y] \geq 0$；因此 $X \leq X'$ 蕴含 $\mathbb{E}[X \mid Y] \leq \mathbb{E}[X' \mid Y]$，且 $|\mathbb{E}[X \mid Y]| \leq \mathbb{E}[|X| \mid Y]$。

(vii) 勾股恒等式：$\mathbb{E}X^2 = \mathbb{E}(\mathbb{E}[X \mid Y])^2 + \mathbb{E}(X - \mathbb{E}[X \mid Y])^2$。

(viii) 收缩性：$\mathbb{E}(\mathbb{E}[X \mid Y])^2 \leq \mathbb{E}X^2$，且 $\mathbb{E}(\mathbb{E}[X \mid Y] - \mathbb{E}[X' \mid Y])^2 \leq \mathbb{E}(X - X')^2$。

证明. (i)、(iv)、(vii)、(viii) 是方框中列出的正交投影性质；(iv) 使用 $L^2(Y) \subset L^2(Y, Y')$。记 $Z = \mathbb{E}[X \mid Y]$ 并使用引理 1.2。(ii) 对 $f \equiv 1$ 检验。(iii) 对有界 g，$g(Y)Z \in L^2(Y)$，且对有界 f 有 $\mathbb{E}[(g(Y)X - g(Y)Z)f(Y)] = \mathbb{E}[(X-Z)(gf)(Y)] = 0$。对一般 g 作截断 $g_M = \max(-M, \min(g, M))$。则 $g_M(Y)X \to g(Y)X$ 于 L^2，故由 (viii)，$\mathbb{E}[g_M(Y)X \mid Y] \to \mathbb{E}[g(Y)X \mid Y]$ 于 L^2；而 $\mathbb{E}[g_M(Y)X \mid Y] = g_M(Y)Z$，且对每个 M，$\|g_M(Y)Z\|_2 \leq \|g_M(Y)X\|_2 \leq \|g(Y)X\|_2$，因此令 $M \to \infty$，得到 $g(Y)Z \in L^2$ 且 $g_M(Y)Z \to g(Y)Z$ 于 L^2。两极限相同。(v) $\mathbb{E}[(X - \mathbb{E}X)f(Y)] = \mathbb{E}[X - \mathbb{E}X]\mathbb{E}f(Y) = 0$。(vi) 对 $f(Y) = \mathbf{1}_{\{Z<0\}}$ 检验：$\mathbb{E}[Z\mathbf{1}_{\{Z<0\}}] = \mathbb{E}[X\mathbf{1}_{\{Z<0\}}] \geq 0$，故 $\mathbb{P}(Z < 0) = 0$；其余结论将线性分别用于 $X' - X \geq 0$ 和 $\pm X \leq |X|$ 即得。 □

定义 1.4 (条件方差)**.** $\operatorname{Var}(X \mid Y) := \mathbb{E}[(X - \mathbb{E}[X \mid Y])^2 \mid Y]$。由 (ii)、(vii)，$\operatorname{Var} X = \mathbb{E}\operatorname{Var}(X \mid Y) + \operatorname{Var}(\mathbb{E}[X \mid Y])$。

引理 1.5 (冻结)**.** 设 $U \in L^2(Y)$ 取值于 $\mathbb{R}^p$，随机变量 Z 取值于 $\mathbb{R}^q$ 且与 Y 独立，$h : \mathbb{R}^p \times \mathbb{R}^q \to \mathbb{R}$ 满足 $h(U, Z) \in L^2$。令 $\overline{h}(u) = \mathbb{E}h(u, Z)$，则 $\mathbb{E}[h(U, Z) \mid Y] = \overline{h}(U)$。

证明. $\overline{h}(U) \in L^2(Y)$。对有界 f，由于 Z 与 (U, Y) 独立，可先对 Z 积分：$\mathbb{E}[h(U, Z)f(Y)] = \mathbb{E}[\overline{h}(U)f(Y)]$。应用引理 1.2。 □

定理 1.6 (高斯条件化，第 1–2 讲)**.** 设 (X, Y) 在 $\mathbb{R}^p \times \mathbb{R}^m$ 中联合高斯，Σ_{YY} 可逆，令 $A = \Sigma_{XY}\Sigma_{YY}^{-1}$。则 $X - AY$ 与 Y 独立，且

$$\mathbb{E}[X \mid Y] = \mu_X + A(Y - \mu_Y), \qquad \operatorname{Var}(X \mid Y) = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}.$$

第一个恒等式逐坐标理解；第二个是条件协方差矩阵，不依赖于 Y。也就是说，对联合高斯的 (X,Y)，所有 Y 的函数中最佳预测是线性的，且给定 Y 时 X 的条件分布为具有所显示均值和协方差的高斯分布。

例 1.7 (非高斯二元组)**.** 设 Y 在 $[-1,1]$ 上均匀，$X=Y^2$（第 2 讲的失效情形）。则 $\operatorname{Cov}(X,Y)=\mathbb{E}Y^3=0$，所以由 Y 预测 X 的最佳线性预测是常数 $\mathbb{E}X=1/3$，残差方差为 $\operatorname{Var}Y^2=4/45$；而由规则 (iii)，$\mathbb{E}[X\mid Y]=Y^2$，残差为零。

2 鞅

2.1 滤过

固定随机变量序列 $Y_1,Y_2,\dots$（每个取值于某个 $\mathbb{R}^m$）。对 $n\ge 0$ 定义

$$\mathbb{E}[X\mid\mathcal{F}_n]:=\mathbb{E}[X\mid Y_1,\dots,Y_n],\qquad\qquad L^2(\mathcal{F}_n):=L^2(Y_1,\dots,Y_n),$$

并令 $\mathbb{E}[X\mid\mathcal{F}_0]:=\mathbb{E}X$、$L^2(\mathcal{F}_0)$ 为常数空间。简记 $\mathbb{E}_n[X]:=\mathbb{E}[X\mid\mathcal{F}_n]$。符号 $\mathcal{F}_n$ 表示 “前 n 个变量”；序列 $(\mathcal{F}_n)_{n\ge0}$ 是由 (Y_n) 生成的滤过。由塔式法则，

$$\mathbb{E}_m\mathbb{E}_n=\mathbb{E}_n\mathbb{E}_m=\mathbb{E}_m\qquad(m\le n).$$

定义 2.1. 若对每个 n 有 $X_n\in L^2(\mathcal{F}_n)$，称序列 $(X_n)_{n\ge0}$ 为适应的；若对每个 $n\ge1$ 有 $X_n\in L^2(\mathcal{F}_{n-1})$，称其为可预测的。

2.2 鞅与正交增量

定义 2.2 (鞅)**.** 令 $(\mathcal{F}_n)$ 为序列 (Y_n) 生成的滤过。L^2 中的序列 $(M_n)_{n\ge0}$ 若适应且对所有 $n\ge0$ 满足 $\mathbb{E}_n[M_{n+1}]=M_n$，则称其为关于 $(\mathcal{F}_n)$ 的鞅；若适应且 $\mathbb{E}_n[M_{n+1}]\ge M_n$，称为次鞅；若适应且 $\mathbb{E}_n[M_{n+1}]\le M_n$，称为上鞅。$M$ 的差分为 $\xi_n=M_n-M_{n-1}$（$n\ge1$）；鞅性质写为 $\mathbb{E}_{n-1}[\xi_n]=0$。

滤过是给定数据的一部分。每个序列 (M_n) 都生成自身的滤过（取 $Y_n=M_n$）；关于滤过 $(\mathcal{F}_n)$ 的鞅也是关于自身滤过的鞅（适应性给出 $L^2(M_0,\dots,M_n)\subset L^2(\mathcal{F}_n)$；再应用塔式法则），但反之不然。下文除非另作说明，“鞅” 均指关于第 2.1 节的滤过的鞅。

由塔式法则，当 $m\le n$ 时 $\mathbb{E}_m[M_n]=M_m$，且 $\mathbb{E}M_n=\mathbb{E}M_0$。反过来，若 $(\xi_n)_{n\ge1}$ 适应且 $\mathbb{E}_{n-1}\xi_n=0$，则对任意常数 M_0，$M_n=M_0+\sum_{k\le n}\xi_k$ 是鞅。

引理 2.3 (正交增量)**.** 设 M 为差分为 ξ_k 的鞅。若 $W\in L^2(\mathcal{F}_{n-1})$，则 $\mathbb{E}[W\xi_n]=0$。因此当 $m\ne n$ 时 $\mathbb{E}[\xi_m\xi_n]=0$，且

$$\mathbb{E}M_n^2=\mathbb{E}M_0^2+\sum_{k=1}^{n}\mathbb{E}\xi_k^2,\qquad\qquad\mathbb{E}(M_n-M_m)^2=\sum_{k=m+1}^{n}\mathbb{E}\xi_k^2\qquad(m\le n).$$

证明. $\mathbb{E}_{n-1}\xi_n=0$ 表明 ξ_n 到 $L^2(\mathcal{F}_{n-1})$ 的投影为 0，即 $\xi_n\perp L^2(\mathcal{F}_{n-1})$（引理 1.2 中取 $Z=0$）。由于 M_0 和 $m<n$ 时的 ξ_m 均属于 $L^2(\mathcal{F}_{n-1})$，$M_n=M_0+\xi_1+\cdots+\xi_n$ 的各项两两正交，所述恒等式即为勾股定理。 □

2.3 例子

例 2.4. (a) **独立变量之和。课堂演算。**设 $Y_1, Y_2, \dots$ 独立且中心化，方差为 $s_k^2 = \mathbb{E}Y_k^2$，令 $S_n = \sum_{k\le n} Y_k$。则

$$S_n, \qquad S_n^2 - \sum_{k\le n} s_k^2, \qquad \frac{e^{\lambda S_n}}{\prod_{k\le n}\mathbb{E}e^{\lambda Y_k}} \quad (\lambda\in\mathbb{R},\ \mathbb{E}e^{2\lambda Y_k}<\infty)$$

都是鞅。确实，由规则 (iii)、(v)，$\mathbb{E}_n S_{n+1} = S_n + \mathbb{E}Y_{n+1} = S_n$；$\mathbb{E}_n[S_{n+1}^2] = S_n^2 + 2S_n\mathbb{E}Y_{n+1} + \mathbb{E}Y_{n+1}^2 = S_n^2 + s_{n+1}^2$；且 $\mathbb{E}_n[e^{\lambda S_{n+1}}] = e^{\lambda S_n}\mathbb{E}e^{\lambda Y_{n+1}}$。对简单随机游走（$Y_k = \pm 1$ 各以概率 $1/2$ 取值），它们为 S_n、$S_n^2 - n$ 和 $e^{\lambda S_n}/(\cosh\lambda)^n$。

(b) **独立同分布情形的指数鞅。**若 Y_k 独立同分布，$\psi(\lambda) = \log\mathbb{E}e^{\lambda Y_1}$，则 (a) 中第三个鞅为 $M_n = \exp(\lambda S_n - n\psi(\lambda))$。

(c) **Doob 鞅。**对 $f(Y_1,\dots,Y_N)\in L^2$，由塔式法则，序列 $M_n = \mathbb{E}_n[f(Y_1,\dots,Y_N)]$ $(0\le n\le N)$ 是鞅，且 $M_0 = \mathbb{E}f$、$M_N = f$。故 $f - \mathbb{E}f = \sum_{k=1}^N \xi_k$，并由引理 2.3，$\operatorname{Var} f = \sum_{k\le N}\mathbb{E}\xi_k^2$。

(d) **随机梯度下降。**设 $\ell(\theta; z)$ 为损失，$\theta\in\mathbb{R}^d$，总体损失 $L(\theta) = \mathbb{E}\ell(\theta; z)$，且假设对每个 θ 都有 $\mathbb{E}\|\nabla\ell(\theta; z)\|^2 < \infty$。设 $z_1, z_2, \dots$ 为独立同分布样本，$\mathcal{F}_n = (z_1,\dots,z_n)$，$\eta_0, \eta_1, \dots$ 为确定性步长，并令

$$\theta_{n+1} = \theta_n - \eta_n\nabla\ell(\theta_n; z_{n+1}), \qquad n\ge 0, \quad \theta_0 \text{ 固定.}$$

则 θ_n 是 $z_1,\dots,z_n$ 的函数，且

$$\theta_{n+1} = \theta_0 - \sum_{k=0}^n \eta_k\nabla L(\theta_k) - M_{n+1},$$
$$M_{n+1} := \sum_{k=0}^n \eta_k(\nabla\ell(\theta_k; z_{k+1}) - \nabla L(\theta_k)), \qquad M_0 := 0.$$

$(M_n)_{n\ge 0}$ 关于 $(\mathcal{F}_n)$ 逐坐标是鞅：它适应，且其差分 $\xi_{k+1} = \eta_k(\nabla\ell(\theta_k; z_{k+1}) - \nabla L(\theta_k))$ 满足 $\mathbb{E}_k\xi_{k+1} = 0$；这是对 $U = \theta_k\in L^2(\mathcal{F}_k)$ 和与 $\mathcal{F}_k$ 独立的 $Z = z_{k+1}$ 使用冻结引理，得到 $\mathbb{E}_k[\nabla\ell(\theta_k; z_{k+1})] = \nabla L(\theta_k)$。故 SGD 迭代等于 θ_0 减去累计的总体梯度步，再减去一个鞅。

译注：对每个确定 θ 有限的梯度二阶矩，不能保证在随机迭代点仍平方可积；还须沿迭代的可积性和 $\nabla\mathbb{E}\ell = \mathbb{E}\nabla\ell$ 的交换依据，例如适当增长 / 控制条件。反例可取中心重尾 z 的密度正比 $(1+|z|)^{-4}$、$\ell(\theta; z) = e^{\theta}z$、$\theta_0 = 0, \eta_0 = \eta_1 = 1$：固定 θ 梯度二阶矩有限，但 $\theta_1 = -z_1$，下一噪声增量 $e^{-z_1}z_2$ 二阶矩无限。因此原假设不足以直接宣称所构造过程为 L^2 鞅。

例 2.5 (似然比)**. 课堂演算。**设 $Y_1, Y_2, \dots$ 独立同分布，密度为 p；q 为另一个密度，满足 $\int q^2/p < \infty$。则

$$M_n = \prod_{k=1}^n \frac{q(Y_k)}{p(Y_k)}$$

是鞅：$\mathbb{E}_n M_{n+1} = M_n\mathbb{E}[q(Y_{n+1})/p(Y_{n+1})] = M_n\int q = M_n$。它非负且 $\mathbb{E}M_n = 1$；若 $q\ne p$，则 $M_n\to 0$ 依概率成立（习题 2.10），因此鞅可以收敛到 0 而其期望始终为 1。

例 2.6 (Pólya 罐模型)**. 课堂演算**。一个罐中有 r 个红球、b 个黑球。每一步均匀随机抽取一个球，放回并增加一个同色球。记 R_n 为 n 次抽取后的红球数，$Y_n=\mathbf{1}\{\text{第}n\text{ 次抽到红球}\}$，$F_n=R_n/(r+b+n)$。则 $\mathbb{E}_n[R_{n+1}]=R_n+F_n$，因此

$$\mathbb{E}_n[F_{n+1}]=\frac{R_n+F_n}{r+b+n+1}=\frac{F_n(r+b+n)+F_n}{r+b+n+1}=F_n.$$

F_n 是取值于 $[0,1]$ 的鞅。其差分为 $\xi_{n+1}=(Y_{n+1}-F_n)/(r+b+n+1)$，且

$$\mathbb{E}_n\xi_{n+1}^2=\frac{F_n(1-F_n)}{(r+b+n+1)^2}\le\frac{1}{4}(r+b+n+1)^{-2},$$

所以 $\sum_n\mathbb{E}\xi_n^2<\infty$。第 3 节表明这迫使 F_n 收敛；习题 3.16 表明极限是随机的。

第 12 讲习题

习题 2.7 (A 类)**.** 直接从第 1.1 节的方框推导命题 1.3 的规则 (iii)、(iv)，即使用 $V\subset W$ 时 $P_VP_W=P_V$，以及当 $Z\in L^2(Y)$、g 有界时 $g(Y)Z\in L^2(Y)$。

习题 2.8 (A 类)**.** 设 (X,Y) 联合高斯，X 为标量，Σ_{YY} 可逆。使用定理 1.6 和各条规则，计算 $\mathbb{E}[X^2\mid Y]$ 和 $\mathbb{E}[e^X\mid Y]$。

习题 2.9 (A 类)**. 译注：** 原题只写一阶均值。若按本文 L^2 Doob 鞅定义作答，还须 $f\in L^2$；仅一阶可积时可在 L^1 条件期望框架写可积 Doob 鞅，但不能自动使用其二阶正交公式。

设 $Y_1,\dots,Y_N$ 独立，均值为 μ_k。分别写出 $f=\sum_{k\le N}Y_k$ 和 $f=\prod_{k\le N}Y_k$ 的 Doob 鞅及其差分。

习题 2.10 (B 类)**.** 在例 2.5 中，证明 $\mathbb{E}\sqrt{M_n}=\rho^n$，其中 $\rho=\int\sqrt{pq}<1$（当 $q\neq p$ 时），并推得对每个 $\varepsilon>0$，$\mathbb{P}(M_n\ge\varepsilon)\to0$。解释为何这不与 $\mathbb{E}M_n=1$ 或第 3 节的 L^2 收敛定理矛盾。

习题 2.11 (Efron–Stein，B 类)**.** 设 $Y_1,\dots,Y_N$ 独立，$f(Y_1,\dots,Y_N)\in L^2$；令 Y_k' 为 Y_k 的独立副本，且与其他所有量独立；记 $f^{(k)}$ 为把 f 中 Y_k 换成 Y_k' 的结果。令 ξ_k 为 Doob 鞅的差分。

(a) 用冻结引理证明 $\mathbb{E}_{k-1}f=\mathbb{E}_kf^{(k)}$，因而 $\xi_k=\mathbb{E}_k[f-f^{(k)}]$。

(b) 用规则 (viii) 证明 $\mathbb{E}\xi_k^2\le\mathbb{E}(f-f^{(k)})^2$。

(c) 推得 $\operatorname{Var}f\le\frac12\sum_{k\le N}\mathbb{E}(f-f^{(k)})^2$，且当 $f=\sum_k g_k(Y_k)$ 时等号成立。

译注： (b) 中常数 1 的界本身只能推出不含 $1/2$ 的和界。(c) 的正确 $1/2$ 还需条件方差对称性：令 $g_k=\mathbb{E}[f\mid Y_1,\dots,Y_k]$，在给定过去时对 Y_k 与独立副本有 $\mathbb{E}\xi_k^2=\frac12\mathbb{E}(g_k(Y_k)-g_k(Y_k'))^2\le\frac12\mathbb{E}(f-f^{(k)})^2$，最后一步对共同未来用 Jensen。原题保留，此为缺少的额外论证。

习题 2.12 (二次函数上的 SGD，C 类)**.** 设 $\epsilon_1,\epsilon_2,\dots$ 独立同分布、中心化，方差为 σ^2；考虑 $L(\theta)=\frac12\mathbb{E}(\theta-\epsilon)^2$ 的 SGD，步长 $\eta_k\in(0,1]$：

$$\theta_{k+1}=\theta_k-\eta_k(\theta_k-\epsilon_{k+1})=(1-\eta_k)\theta_k+\eta_k\epsilon_{k+1}.$$

(a) 仿照例 2.4(d) 写出 $\theta_{n+1}=\theta_0-\sum_{k\le n}\eta_kL'(\theta_k)-M_{n+1}$，显式给出 M_{n+1}。

(b) 推导 $\mathbb{E}\theta_{n+1}^2 = (1-\eta_n)^2\mathbb{E}\theta_n^2 + \eta_n^2\sigma^2$ 并求解。

(c) 证明若 $\eta_n \to 0$ 且 $\sum \eta_n = \infty$，则 $\mathbb{E}\theta_n^2 \to 0$；证明当 $\eta_n \equiv \eta$ 为常数时，$\mathbb{E}\theta_n^2 \to \eta\sigma^2/(2-\eta)$。

(d) 写出 $\theta_n = \theta_0 \prod_{k<n}(1-\eta_k) + \sum_{k<n} w_{n,k}\epsilon_{k+1}$，其中权重 $w_{n,k}$ 显式给出。(η_k) 满足什么条件使 $\sum_k \eta_k\epsilon_{k+1}$ 在 L^2 中收敛？（下文定理 3.10。）

3 分解、停时与收敛

本节始终设 M 为关于第 2.1 节滤过的鞅，其差分为 ξ_k。

3.1 Doob 分解与二次变差

命题 3.1 (Doob 分解)**.** 设 $(X_n)_{n\ge 0}$ 适应。将 $X_n = X_0 + M_n + A_n$ 写成 M 为鞅、A 可预测且 $M_0 = A_0 = 0$ 的形式，恰有一种方式，即

$$A_n = \sum_{k=1}^{n} (\mathbb{E}_{k-1}X_k - X_{k-1}), \qquad M_n = \sum_{k=1}^{n} (X_k - \mathbb{E}_{k-1}X_k).$$

X 是次鞅当且仅当 A 非减。

证明. 显示出的 A 可预测，显示出的 M 满足 $\mathbb{E}_{k-1}[X_k - \mathbb{E}_{k-1}X_k] = 0$，且它们之和为 $X_n - X_0$。若 $X_0 + M' + A'$ 是另一种此类分解，则 $M - M' = A' - A$ 是可预测鞅，所以 $M_n - M'_n = \mathbb{E}_{n-1}[M_n - M'_n] = M_{n-1} - M'_{n-1} = \cdots = 0$。最后的结论从 $A_n - A_{n-1} = \mathbb{E}_{n-1}X_n - X_{n-1}$ 直接读出。 □

定义 3.2 (条件方差与二次变差)**.** 令 $\sigma_k^2 := \mathbb{E}_{k-1}[\xi_k^2]$，$\langle M\rangle_n := \sum_{k=1}^n \sigma_k^2$。

引理 3.3. M_n^2 是次鞅，$M_n^2 - \langle M\rangle_n$ 是鞅，且 $\mathbb{E}\langle M\rangle_n = \mathbb{E}M_n^2 - \mathbb{E}M_0^2$。等价地，$\langle M\rangle$ 是 M^2 的 Doob 分解中的可预测部分。

证明.

$$\begin{aligned}\mathbb{E}_{n-1}[M_n^2] - M_{n-1}^2 &= \mathbb{E}_{n-1}[(M_{n-1}+\xi_n)^2] - M_{n-1}^2 \\ &= 2M_{n-1}\mathbb{E}_{n-1}\xi_n + \mathbb{E}_{n-1}\xi_n^2 = \sigma_n^2 \ge 0.\end{aligned}$$

□

3.2 停时与可选停时

定义 3.4 (停时)**.** 取值于 $\{0,1,2,\ldots\}\cup\{\infty\}$ 的随机变量 τ 若对每个 n 都有 $\mathbf{1}_{\{\tau\le n\}} \in L^2(\mathcal{F}_n)$，则称为停时；即 $\tau \le n$ 是否成立是 $Y_1,\ldots,Y_n$ 的函数。

适应序列首次进入集合 B 的时间 $\min\{n : X_n \in B\}$ 是停时；对常数 N，$\tau \wedge N = \min(\tau, N)$ 也是停时；最后一次访问 B 则不是。对停时 τ，停止后的序列为 $(M_{n\wedge\tau})_{n\ge 0}$。

命题 3.5 (停止后的鞅)**.** 若 M 是鞅（次鞅、上鞅）且 τ 为停时，则 $(M_{n\wedge\tau})_{n\ge 0}$ 是鞅（次鞅、上鞅），其差分为 $\mathbf{1}_{\{\tau>n\}}\xi_{n+1}$。

证明. $M_{n\wedge\tau}$ 是 $Y_1,\dots,Y_n$ 的函数且属于 L^2（它是 $M_0,\dots,M_n$ 之一）。由于 $M_{(n+1)\wedge\tau}-M_{n\wedge\tau}=\mathbf{1}_{\{\tau>n\}}\xi_{n+1}$，且 $\mathbf{1}_{\{\tau>n\}}=1-\mathbf{1}_{\{\tau\le n\}}\in L^2(\mathcal{F}_n)$ 有界，由规则 (iii)，$\mathbb{E}_n[\mathbf{1}_{\{\tau>n\}}\xi_{n+1}]=\mathbf{1}_{\{\tau>n\}}\mathbb{E}_n\xi_{n+1}$，它等于 0（分别为 ≥ 0、≤ 0）。 □

推论 3.6 (可选停时，有界情形)**.** 设停时 $\tau\le N$，受常数 N 约束。若 M 是鞅，则 $\mathbb{E}M_\tau=\mathbb{E}M_0$。若 X 是次鞅，则 $\mathbb{E}X_0\le\mathbb{E}X_\tau\le\mathbb{E}X_N$；上鞅的不等式方向相反。

证明. $M_\tau=M_{N\wedge\tau}$，而停止后的鞅均值恒定，故 $\mathbb{E}M_\tau=\mathbb{E}M_{0\wedge\tau}=\mathbb{E}M_0$；对次鞅，同一论证给出 $\mathbb{E}X_\tau\ge\mathbb{E}X_0$。对上界，

$$X_N-X_\tau=\sum_{k=1}^{N}\mathbf{1}_{\{\tau\le k-1\}}(X_k-X_{k-1}),$$

且每项满足

$$\mathbb{E}[\mathbf{1}_{\{\tau\le k-1\}}(X_k-X_{k-1})]=\mathbb{E}[\mathbf{1}_{\{\tau\le k-1\}}\mathbb{E}_{k-1}(X_k-X_{k-1})]\ge 0.$$

□

不能去掉 τ 有界这一条件：对简单随机游走和 $\tau=\min\{n:S_n=1\}$，$\mathbb{E}S_\tau=1\ne 0=\mathbb{E}S_0$。对无界的 τ，可将推论用于 $\tau\wedge n$ 并取极限，如下所示。

例 3.7 (赌徒破产)**. 课堂演算**。设 S 是简单对称随机游走，a,b 为正整数，$\tau=\min\{n:S_n\in\{-b,a\}\}$，$c=\max(a,b)$。

τ **有限**。S_n^2-n 是鞅（例 2.4(a)），$\tau\wedge n$ 有界，故 $\mathbb{E}(\tau\wedge n)=\mathbb{E}S_{\tau\wedge n}^2\le c^2$。因此 $\mathbb{P}(\tau>n)=\mathbb{P}(\tau\wedge n=n)\le\mathbb{E}(\tau\wedge n)/n\le c^2/n\to 0$。

译注： 原文首个等号有端点错误：$\{\tau\wedge n=n\}=\{\tau\ge n\}$，不是 $\{\tau>n\}$。将首个等号改读为 $\le$ 即可保留尾界及赌徒破产结论；例如 $a=b=1,n=1$ 时两事件概率分别为 0 和 1。

退出概率。$0=\mathbb{E}S_{\tau\wedge n}$，且 $|S_{\tau\wedge n}-S_\tau\mathbf{1}_{\{\tau\le n\}}|\le c\mathbf{1}_{\{\tau>n\}}$，所以 $|\mathbb{E}[S_\tau\mathbf{1}_{\{\tau\le n\}}]|\le c\mathbb{P}(\tau>n)\to 0$。令 $p=\mathbb{P}(S_\tau=a)$，得到 $pa-(1-p)b=0$，即

$$\mathbb{P}(S_\tau=a)=\frac{b}{a+b},\qquad \mathbb{P}(S_\tau=-b)=\frac{a}{a+b}.$$

期望退出时间。$\mathbb{E}(\tau\wedge n)=\mathbb{E}S_{\tau\wedge n}^2\to\mathbb{E}S_\tau^2=a^2\frac{b}{a+b}+b^2\frac{a}{a+b}=ab$。左侧的收敛为 $\mathbb{E}(\tau\wedge n)=\sum_{m<n}\mathbb{P}(\tau>m)\uparrow\mathbb{E}\tau$，右侧同上。故 $\mathbb{E}\tau=ab$。

例 3.8 (Wald 恒等式)**. 课堂演算**。设 $Y_1,Y_2,\dots$ 独立同分布，均值为 μ、方差有限，$S_n=\sum_{k\le n}Y_k$，τ 是满足 $\mathbb{E}\tau<\infty$ 的停时。则 $\mathbb{E}S_\tau=\mu\mathbb{E}\tau$。证明：$S_n-n\mu$ 是鞅，故由推论 3.6，$\mathbb{E}S_{\tau\wedge n}=\mu\mathbb{E}(\tau\wedge n)$，右侧趋于 $\mu\mathbb{E}\tau$。对左侧写

$$S_\tau-S_{\tau\wedge n}=\sum_{k>n}\mathbf{1}_{\{\tau\ge k\}}(Y_k-\mu)+\mu(\tau-n)_+.$$

第一项之和的各项为鞅差，因为 $\mathbf{1}_{\{\tau\ge k\}}\in L^2(\mathcal{F}_{k-1})$。由引理 2.3，其二阶矩为

$$\operatorname{Var}(Y_1)\sum_{k>n}\mathbb{P}(\tau\ge k)=\operatorname{Var}(Y_1)\mathbb{E}(\tau-n)_+.$$

因此

$$\mathbb{E}|S_\tau-S_{\tau\wedge n}|\le\sqrt{\operatorname{Var}(Y_1)\mathbb{E}(\tau-n)_+}+|\mu|\mathbb{E}(\tau-n)_+\longrightarrow 0,$$

且 $\mathbb{E}S_{\tau\wedge n}\to\mathbb{E}S_\tau$。

3.3 最大不等式与 L^2 收敛

命题 3.9 (Doob 最大不等式)**.** 对每个 n 和 $u>0$，

$$\mathbb{P}\left(\max_{k\le n}|M_k|\ge u\right)\le\frac{\mathbb{E}M_n^2}{u^2},\qquad\qquad \mathbb{E}\max_{k\le n}M_k^2\le 4\mathbb{E}M_n^2.$$

证明. 令 $\tau=\min\{k\le n:|M_k|\ge u\}$；若不存在这样的 k 则令 $\tau=n$。$\tau\le n$ 为停时。M^2 是次鞅（引理 3.3），所以由推论 3.6，

$$\mathbb{E}M_n^2\ge\mathbb{E}M_\tau^2\ge\mathbb{E}[M_\tau^2\mathbf{1}_{\{\max_{k\le n}|M_k|\ge u\}}]\ge u^2\mathbb{P}\left(\max_{k\le n}|M_k|\ge u\right).$$

第二个不等式是习题 3.13。 □

定理 3.10 (L^2 收敛)**.** 假设 $\sum_{k\ge1}\mathbb{E}\xi_k^2<\infty$，等价地 $\sup_n\mathbb{E}M_n^2<\infty$。则：

(i) 存在 $M_\infty\in L^2$ 使 $\mathbb{E}(M_n-M_\infty)^2=\sum_{k>n}\mathbb{E}\xi_k^2\to0$，且对每个 n 有 $\mathbb{E}_nM_\infty=M_n$；

(ii) 对每个 n 和 $u>0$，$\mathbb{P}(\sup_{k\ge n}|M_k-M_n|\ge u)\le u^{-2}\sum_{k>n}\mathbb{E}\xi_k^2$。

证明. (i) 对 $n<m$，$\mathbb{E}(M_n-M_m)^2=\sum_{k=n+1}^m\mathbb{E}\xi_k^2$（引理 2.3），故 (M_n) 在 L^2 中为 Cauchy 序列，由完备性收敛到某个 M_∞，且 $\mathbb{E}(M_n-M_\infty)^2=\lim_m\mathbb{E}(M_n-M_m)^2$。由于 $m\ge n$ 时 $\mathbb{E}_nM_m=M_n$，而 $\mathbb{E}_n$ 为收缩映射（规则 (viii)），故 $\mathbb{E}_nM_\infty=\lim_m\mathbb{E}_nM_m=M_n$。(ii) 固定 n，$(M_k-M_n)_{k\ge n}$ 是鞅，差分为 $k>n$ 时的 ξ_k。对时间范围 m 应用命题 3.9，得到 $\mathbb{P}(\max_{n\le k\le m}|M_k-M_n|\ge u)\le u^{-2}\sum_{k=n+1}^m\mathbb{E}\xi_k^2$；令 $m\to\infty$。 □

陈述 (ii) 控制时间 n 之后路径的整个未来；后面将以此形式使用收敛性。

译注： 对有限时域令其增大直接控制的是“某个时刻达到阈值”，而 $\sup\ge u$ 可能只逼近 u。可先对任意 $b<u$ 用最大不等式，利用 $\{\sup\ge u\}\subset\{\exists k:|M_k-M_n|\ge b\}$，再令 $b\uparrow u$，补足端点细节。

例 3.11 (加权和)**.** 设 $\epsilon_1,\epsilon_2,\dots$ 为鞅差，$\mathbb{E}_{k-1}\epsilon_k^2\le1$，$a_k$ 可预测且有界，并满足 $\sum_k\mathbb{E}a_k^2<\infty$。则 $M_n=\sum_{k\le n}a_k\epsilon_k$ 为鞅，其 $\sigma_k^2=a_k^2\mathbb{E}_{k-1}\epsilon_k^2\le a_k^2$，定理 3.10 适用。特别地，对确定性 η_k，只要 $\sum_k\eta_k^2<\infty$，$\sum_k\eta_k\epsilon_k$ 就在 L^2 中收敛。这是 SGD 步长的 Robbins–Monro 条件（第 16 讲）。

例 3.12 (随机级数)**. 课堂演算。**设 ϵ_k 为独立同分布的随机符号。$\sum_k\epsilon_k/k$ 在 L^2 中收敛，因为 $\sum_k k^{-2}<\infty$。$\sum_k\epsilon_k/\sqrt{k}$ 则不收敛：$\mathbb{E}M_n^2=\sum_{k\le n}1/k\to\infty$，而 $\mathbb{E}(M_m-M_n)^2=\sum_{n<k\le m}1/k$ 当 $n,m\to\infty$ 时不趋于零。对 Pólya 罐模型（例 2.6），$\sum_n\mathbb{E}\xi_n^2<\infty$，故 $F_n\to F_\infty$ 于 L^2 中，且 $\mathbb{E}F_\infty=r/(r+b)$。

第 13 讲习题

习题 3.13 (B 类)**.** 令 $M_n^*=\max_{k\le n}|M_k|$。

(a) 证明 $|M|$ 是次鞅（规则 (vi)）。

(b) 精化命题 3.9 的证明，得到 $u\mathbb{P}(M_n^*\ge u)\le\mathbb{E}[|M_n|\mathbf{1}_{\{M_n^*\ge u\}}]$。

(c) 使用 $\mathbb{E}Z^2=\int_0^\infty 2u\mathbb{P}(Z\ge u)\,du$ 和 Cauchy–Schwarz，推得 $\mathbb{E}(M_n^*)^2\le 4\mathbb{E}M_n^2$。

习题 3.14 (A 类)**.** 对下列过程计算 $\langle M\rangle_n$：简单随机游走；例 2.4(a) 的指数鞅；$f=\sum_{k\le N}Y_k$、Y_k 独立时的 Doob 鞅；例 2.5 的似然比。

习题 3.15 (B 类)**.** 设 S 为简单对称随机游走，$\tau_1=\min\{n:S_n=1\}$。

(a) 在例 3.7 中取 $a=1$ 并令 $b\to\infty$，证明 $\mathbb{P}(\tau_1<\infty)=1$。

(b) 证明 $\mathbb{E}\tau_1=\infty$（若有限，Wald 恒等式将给出 $1=\mathbb{E}S_{\tau_1}=0$）。

(c) 对鞅 $e^{\lambda S_n}/(\cosh\lambda)^n$ 在 $\tau_1\wedge n$ 处应用推论 3.6，令 $n\to\infty$，计算 $\lambda>0$ 时的 $\mathbb{E}[(\cosh\lambda)^{-\tau_1}]$。

习题 3.16 (Pólya 罐模型的完成，B 类)**.** 接续例 2.6。

(a) 对 $r=b=1$，归纳证明 R_n 在 $\{1,\dots,n+1\}$ 上均匀，从而 L^2 极限 F_∞ 在 $[0,1]$ 上均匀。

(b) 由条件方差计算一般 r,b 的 $\operatorname{Var}F_n$，并确定 $\operatorname{Var}F_\infty$。

(c) 证明 $\mathbb{E}[F_\infty\mid F_n]=F_n$ 并解释：罐中最终组成是随机的，但时间 n 时对它的最佳猜测是当前比例。

习题 3.17 (分支过程，C 类)**.** 设 $Z_0=1$、$Z_{n+1}=\sum_{i=1}^{Z_n}\zeta_{n+1,i}$，其中各 $\zeta_{n,i}$ 为独立同分布的非负整数，均值为 m、方差为 s^2，且独立于过去。

(a) 用冻结引理证明 $\mathbb{E}_nZ_{n+1}=mZ_n$，故 $W_n=Z_n/m^n$ 是鞅。

(b) 用定义 1.4 证明 $\operatorname{Var}Z_{n+1}=s^2m^n+m^2\operatorname{Var}Z_n$，因此 $\operatorname{Var}W_{n+1}=\operatorname{Var}W_n+s^2/m^{n+2}$。

(c) 当 $m>1$ 时推得 $\sup_n\mathbb{E}W_n^2<\infty$，所以 $W_n\to W_\infty$ 于 L^2，且 $\mathbb{E}W_\infty=1$、$\operatorname{Var}W_\infty=s^2/[m(m-1)]$。

(d) 对 $m=1.5$ 的 Poisson 子代进行模拟，画出若干次运行中 W_n 的轨迹。

4 鞅中心极限定理

第 3–4 讲逐个将独立求和项替换为高斯变量，证明了中心极限定理。对鞅差而言，每一步的条件方差是随机的，所以混合变量中的高斯部分被设定为携带剩余的条件方差。

4.1 陈述

固定 k 及鞅差 $\xi_1,\dots,\xi_k$，满足 $\mathbb{E}|\xi_i|^3<\infty$，条件方差 $\sigma_i^2=\mathbb{E}_{i-1}\xi_i^2$，并令

$$S_j=\sum_{i\le j}\xi_i,\qquad V_j=\sum_{i\le j}\sigma_i^2=\langle S\rangle_j,\qquad S_0=V_0=0.$$

定理 4.1 (鞅中心极限定理，定量形式)**.** 假设 $V_k\le 1$。则对每个 $f\in C^4(\mathbb{R})$，其 f',f'',f''',f'''' 有界，且 $g\sim\mathcal{N}(0,1)$，

$$|\mathbb{E}f(S_k)-\mathbb{E}f(g)|\le\frac{\|f'''\|_\infty}{6}\sum_{i=1}^k\mathbb{E}|\xi_i|^3+\frac{\|f''''\|_\infty}{8}\sum_{i=1}^k\mathbb{E}\sigma_i^4+\frac{\|f''\|_\infty}{2}\mathbb{E}(1-V_k).$$

由于 $\sum_i\sigma_i^4\le V_k\max_i\sigma_i^2\le\max_i\sigma_i^2$，第二项至多为 $\frac18\|f''''\|_\infty\mathbb{E}\max_i\sigma_i^2$。

推论 4.2 (鞅中心极限定理)**.** 对每个 n，设 $\xi_{n,1},\dots,\xi_{n,k_n}$ 为鞅差（滤过可依赖于 n），条件方差为 $\sigma_{n,i}^2$，且 $V_{n,k_n}=\sum_i \sigma_{n,i}^2 \le 1$。若

$$\sum_i \mathbb{E}|\xi_{n,i}|^3 \to 0, \qquad \mathbb{E}\max_i \sigma_{n,i}^2 \to 0, \qquad \mathbb{E}(1-V_{n,k_n}) \to 0,$$

则 $\sum_i \xi_{n,i} \Rightarrow \mathcal{N}(0,1)$。

证明. 由定理 4.1，对所有各阶导数均有界的光滑 f，$\mathbb{E}f(S_{n,k_n}) \to \mathbb{E}f(g)$；而这类检验函数决定依分布收敛（第 3–4 讲）。 □

4.2 证明

引理 4.3 (热半群)**.** 对定理 4.1 中的 f 和 $g\sim\mathcal{N}(0,1)$，令 $\phi(x,v)=\mathbb{E}f(x+\sqrt{v}\,g)$，$x\in\mathbb{R}$、$v\ge 0$。则 $\phi(x,0)=f(x)$、$\phi(0,1)=\mathbb{E}f(g)$，且 $\partial_x^j\phi(x,v)=\mathbb{E}f^{(j)}(x+\sqrt{v}\,g)$，故 $\|\partial_x^j\phi\|_\infty \le \|f^{(j)}\|_\infty$ $(j\le 4)$。对 $v>0$，

$$\partial_v\phi = \tfrac{1}{2}\partial_{xx}\phi.$$

因此对 $0\le v'<v$，$\phi(x,v)-\phi(x,v')=\frac{1}{2}\int_{v'}^{v}\partial_{xx}\phi(x,s)\,ds$。

证明. 导数有界保证可在 $\mathbb{E}$ 内求导。对热方程，将 Stein 恒等式 $\mathbb{E}[gh(g)]=\mathbb{E}h'(g)$（第 3–4 讲）应用于 $h(y)=f'(x+\sqrt{v}\,y)$：

$$\partial_v\phi(x,v)=\mathbb{E}\left[f'(x+\sqrt{v}\,g)\frac{g}{2\sqrt{v}}\right]=\frac{1}{2\sqrt{v}}\mathbb{E}h'(g)=\frac{1}{2}\mathbb{E}f''(x+\sqrt{v}\,g).$$

当 $v'>0$ 时积分公式由微积分基本定理成立；利用 $|\phi(x,v')-\phi(x,0)|\le\|f'\|_\infty\sqrt{v'}\,\mathbb{E}|g|$，令 $v'\downarrow 0$。 □

定理 4.1 的证明. 由于 $\phi(S_0,1-V_0)=\mathbb{E}f(g)$ 且 $\phi(S_k,0)=f(S_k)$，

$$\begin{aligned}\mathbb{E}f(S_k)-\mathbb{E}f(g) &= \mathbb{E}[\phi(S_k,0)-\phi(S_k,1-V_k)]\\ &\quad+\sum_{i=1}^{k}\mathbb{E}[\phi(S_i,1-V_i)-\phi(S_{i-1},1-V_{i-1})].\end{aligned}$$

第一项。由积分公式，$|\phi(x,0)-\phi(x,v)|\le\frac{v}{2}\|f''\|_\infty$，故第一项的绝对值至多为 $\frac{1}{2}\|f''\|_\infty\mathbb{E}(1-V_k)$。

第 i 步。写 $x=S_{i-1}$、$v=1-V_{i-1}$、$\sigma^2=\sigma_i^2$、$\xi=\xi_i$；则 $x,v,\sigma^2\in L^2(\mathcal{F}_{i-1})$，且 $v-\sigma^2=1-V_i\ge 0$。拆分

$$\begin{aligned}\phi(x+\xi,v-\sigma^2)-\phi(x,v) &= \underbrace{\phi(x+\xi,v-\sigma^2)-\phi(x,v-\sigma^2)}_{I}\\ &\quad+\underbrace{\phi(x,v-\sigma^2)-\phi(x,v)}_{II}.\end{aligned}$$

对 x 作 Taylor 展开：

$$I=\xi\partial_x\phi(x,v-\sigma^2)+\tfrac{\xi^2}{2}\partial_{xx}\phi(x,v-\sigma^2)+R, \qquad |R|\le\frac{\|f'''\|_\infty}{6}|\xi|^3.$$

系数有界且属于 $L^2(\mathcal{F}_{i-1})$，故由规则 (iii)，

$$\mathbb{E}_{i-1} I = \frac{\sigma^2}{2}\partial_{xx}\phi(x, v-\sigma^2) + \mathbb{E}_{i-1}R.$$

由积分公式，

$$\begin{aligned} II &= -\frac{1}{2}\int_{v-\sigma^2}^{v} \partial_{xx}\phi(x,s)\,ds \\ &= -\frac{\sigma^2}{2}\partial_{xx}\phi(x, v-\sigma^2) - \frac{1}{2}\int_{v-\sigma^2}^{v} [\partial_{xx}\phi(x,s) - \partial_{xx}\phi(x, v-\sigma^2)]\,ds, \end{aligned}$$

于是 $\mathbb{E}_{i-1}I$ 与 II 的主项抵消。由于 $\partial_s\partial_{xx}\phi = \frac{1}{2}\partial_x^4\phi$ 由 $\frac{1}{2}\|f''''\|_\infty$ 约束，被积函数的绝对值至多为 $\frac{1}{2}\|f''''\|_\infty(s - v + \sigma^2)$，积分项至多为

$$\frac{1}{4}\|f''''\|_\infty \int_0^{\sigma^2} t\,dt = \frac{\|f''''\|_\infty}{8}\sigma^4.$$

因此

$$|\mathbb{E}_{i-1}[I + II]| \le \frac{\|f'''\|_\infty}{6}\mathbb{E}_{i-1}|\xi_i|^3 + \frac{\|f''''\|_\infty}{8}\sigma_i^4.$$

取期望并对 i 求和。 □

注 4.4 (去掉 $V_k \le 1$)**.** $\{V_i \le 1\}$ 在时间 $i-1$ 已确定（因为 $V_i = V_{i-1} + \sigma_i^2$，且 $\sigma_i^2 \in L^2(\mathcal{F}_{i-1})$），所以 $\xi_i' = \xi_i \mathbf{1}_{\{V_i \le 1\}}$ 是鞅差，其条件方差为 $\sigma_i^2 \mathbf{1}_{\{V_i\le 1\}}$，累计方差 $V_k' \le 1$。由引理 2.3，

$$\mathbb{E}(S_k - S_k')^2 = \mathbb{E}\sum_{i:V_i>1}\sigma_i^2 \le \mathbb{E}(V_k - 1)_+ + \mathbb{E}\max_i \sigma_i^2.$$

所以将定理 4.1 应用于 S_k'，便可在上述误差范围内控制 S_k；并且推论 4.2 中的 $V_{n,k_n} \le 1$ 可换成 $\mathbb{E}|V_{n,k_n} - 1| \to 0$。

注 4.5 (独立求和项)**.** 若 ξ_i 独立，方差 σ_i^2 之和为 1，则 $V_k = 1$，界变为

$$|\mathbb{E}f(S_k) - \mathbb{E}f(g)| \le \frac{\|f'''\|_\infty}{6}\sum_i \mathbb{E}|\xi_i|^3 + \frac{\|f''''\|_\infty}{8}\sum_i \sigma_i^4.$$

第 3–4 讲的混合变量 $\sum_{j\le i}\xi_j + \sum_{j>i} g_j$ 现在变成 $S_i + \sqrt{1-V_i}\,g$。

4.3 例子

例 4.6 (独立同分布的求和项)**. 课堂演算**。设 $X_1, \dots, X_n$ 独立同分布、中心化，方差为 1 且 $\mathbb{E}|X_1|^3 < \infty$，令 $\xi_i = X_i/\sqrt{n}$。则 $\sigma_i^2 = 1/n$、$V_n = 1$、$\sum \mathbb{E}|\xi_i|^3 = \mathbb{E}|X_1|^3/\sqrt{n}$、$\sum \sigma_i^4 = 1/n$，由定理 4.1，

$$|\mathbb{E}f(S_n) - \mathbb{E}f(g)| \le \frac{\|f'''\|_\infty \mathbb{E}|X_1|^3}{6\sqrt{n}} + \frac{\|f''''\|_\infty}{8n}.$$

例 4.7 (自适应收集的数据)**. 课堂演算**。设 $\epsilon_1, \epsilon_2, \dots$ 独立同分布、中心化，方差为 1 且 $\mathbb{E}|\epsilon_1|^3 < \infty$，适应于滤过 $(\mathcal{F}_i)$，其中 ϵ_i 与 $\mathcal{F}_{i-1}$ 独立。设 a_i 可预测且 $|a_i| \le A$。则 $\xi_i = a_i\epsilon_i$ 是鞅差，且

$$\sigma_i^2 = a_i^2, \qquad \mathbb{E}_{i-1}|\xi_i|^3 = |a_i|^3\mathbb{E}|\epsilon_1|^3, \qquad V_k = \sum_{i\le k} a_i^2.$$

令确定性的 $v_k \to \infty$ 满足 $\mathbb{E}|V_k/v_k - 1| \to 0$。归一化差分 $a_i\epsilon_i/\sqrt{v_k}$ 满足

$$\sum_i \mathbb{E}|\cdot|^3 \le A\mathbb{E}|\epsilon_1|^3 \mathbb{E}V_k / v_k^{3/2} \to 0, \qquad \max_i \sigma_i^2/v_k \le A^2/v_k \to 0.$$

因此由推论 4.2 和注 4.4，

$$\frac{1}{\sqrt{v_k}} \sum_{i\le k} a_i\epsilon_i \Rightarrow \mathcal{N}(0,1).$$

这涵盖协变量 a_i 选为过去响应的函数时的最小二乘（多臂老虎机、主动学习、序贯实验）：见习题 4.10、4.11。

第 14 讲习题

习题 4.8 (A 类)**.** 设 ξ_i 独立、中心化，方差为 σ_i^2，且 $\sum_{i\le k}\sigma_i^2 = 1$。从定理 4.1 推得第 3–4 讲的 Lindeberg 定理（在三阶矩条件下），并比较误差界。

习题 4.9 (A 类)**.** 当 $f(x) = e^{i\theta x}$ 以及 $f(x) = x^4$ 时，直接验证 $\phi(x,v) = \mathbb{E}f(x + \sqrt{v}\,g)$ 求解 $\partial_v\phi = \tfrac{1}{2}\partial_{xx}\phi$。

习题 4.10 (双臂老虎机，B 类)**.** 两只臂给出奖励 $\mu_1 + \epsilon$ 和 $\mu_2 + \epsilon$，其中 ϵ 如例 4.7。每轮玩家以概率 $1-\delta$ 选择当前经验均值较大的臂，以概率 $\delta \in (0, 1/2)$ 选择另一只臂，所用硬币独立。令 $N_1(n)$ 为前 n 轮选择臂 1 的次数，$\widehat{\mu}_1(n)$ 为其经验均值。

(a) 证明 $N_1(n)$ 支配一个 $\mathrm{Bin}(n,\delta)$ 变量，故 $N_1(n) \to \infty$。

(b) 写出 $N_1(n)(\widehat{\mu}_1(n) - \mu_1) = \sum_{i\le n} a_i\epsilon_i$，其中 $a_i \in \{0,1\}$ 可预测。

(c) 假设 $N_1(n)/n \to p_1 \in (0,1)$ 于 L^2，证明 $\sqrt{N_1(n)}(\widehat{\mu}_1(n) - \mu_1) \Rightarrow \mathcal{N}(0,1)$。

习题 4.11 (自回归的最小二乘，C 类)**.** 设 $X_0 = 0$、$X_{k+1} = \rho X_k + \epsilon_{k+1}$，其中 $|\rho| < 1$，ϵ_k 独立同分布于 $\mathcal{N}(0,\sigma^2)$。由 $X_0,\dots,X_n$ 得到的 ρ 的最小二乘估计满足

$$\widehat{\rho}_n - \rho = \frac{\sum_{k<n} X_k\epsilon_{k+1}}{\sum_{k<n} X_k^2}.$$

(a) 证明分子 M_n 是鞅，且 $\sigma_{k+1}^2 = \sigma^2 X_k^2$。

(b) 证明 $\mathbb{E}X_k^2 \to \sigma^2/(1-\rho^2)$，且 $\mathrm{Var}(n^{-1}\sum_{k<n}X_k^2) = O(1/n)$（对四阶矩使用 Wick 定理；$\mathrm{Cov}(X_j^2, X_k^2)$ 按 $|j-k|$ 几何衰减），故 $n^{-1}\sum_{k<n}X_k^2 \to \sigma^2/(1-\rho^2)$ 于 L^2。

(c) 对 $M_n/\sqrt{n\sigma^4/(1-\rho^2)}$ 应用推论 4.2 与注 4.4，推得 $\sqrt{n}(\widehat{\rho}_n - \rho) \Rightarrow \mathcal{N}(0, 1-\rho^2)$（可引用：除以一个依概率收敛到正的常数的序列不改变依分布极限）。

(d) 对 $\rho = 0.9$、$n = 2000$ 模拟 10^3 次，与预测的高斯分布比较。

译注： 括号内 Slutsky 说法若指极限分布不变则不正确：$A_n \Rightarrow A$、$B_n \to c > 0$ 依概率蕴含 $A_n/B_n \Rightarrow A/c$。本题已写的 $\mathcal{N}(0, 1-\rho^2)$ 正确计入了该缩放，且需要非退化噪声以定义估计量。

习题 4.12 (二次函数上的 SGD：涨落，C 类)**.** 在习题 2.12 中取 $\eta_k = \eta/k$，其中 $\eta > 1/2$ 且 $\mathbb{E}|\epsilon_1|^3 < \infty$。

译注：此前迭代从 $k=0$ 起，而 η/k 在 0 无定义，须约定正指标起点或另给初始步；$\eta > 1$ 也可能使初期步长违反先前 $\eta_k \le 1$。原题 (a) 的相对渐近不对所有固定早期 k 一致：对正指标 $w_{n,k} = (\eta/k)\prod_{j=k+1}^{n-1}(1-\eta/j)$，$\eta = 3/4, k = 1$ 时，与 $(\eta/k)(k/n)^\eta$ 的比趋于 $1/\Gamma(5/4) \simeq 1.10326265$，不是 1。通常须 k 增长，早期权重另控；此处保留原题，不补造自举证明。

(a) 证明权重满足 $w_{n,k} = \frac{\eta}{k}(k/n)^\eta(1+o(1))$，对 $k \le n$ 一致成立。

(b) 证明 $n \operatorname{Var}\theta_n \to \eta^2\sigma^2/(2\eta-1)$。

(c) 应用定理 4.1（各求和项独立，故 V_k 确定）证明 $\sqrt{n}\,\theta_n \Rightarrow \mathcal{N}(0, \eta^2\sigma^2/(2\eta-1))$。当 $\eta < 1/2$ 时有什么变化？

5 集中不等式

本节始终设 M 为鞅，差分为 ξ_k，条件方差为 σ_k^2。

5.1 Azuma–Hoeffding 不等式

引理 5.1 (Hoeffding 引理)**.** 设 $\mathbb{E}\xi = 0$，且对常数 a, c 有 $a \le \xi \le a + c$。则对所有 $\lambda \in \mathbb{R}$，$\mathbb{E}e^{\lambda\xi} \le e^{\lambda^2 c^2/8}$。条件形式：若 $\mathbb{E}_{k-1}\xi = 0$、$A \le \xi \le A + c$，其中 $A \in L^2(\mathcal{F}_{k-1})$、$c$ 为常数，则 $\mathbb{E}_{k-1}e^{\lambda\xi} \le e^{\lambda^2 c^2/8}$。

证明. 我们证明 $|\xi| \le c$ 的情形，常数为 $e^{\lambda^2 c^2/2}$；尖锐常数留作习题 5.13。由 $x \mapsto e^{\lambda x}$ 在 $[-c, c]$ 上的凸性，

$$e^{\lambda\xi} \le \frac{c-\xi}{2c}e^{-\lambda c} + \frac{c+\xi}{2c}e^{\lambda c},$$

故 $\mathbb{E}e^{\lambda\xi} \le \cosh(\lambda c) \le e^{\lambda^2 c^2/2}$；最后一步通过比较 Taylor 级数得到（$(2k)! \ge 2^k k!$）。条件形式对 $\mathbb{E}_{k-1}$ 作相同计算即可（规则 (iii)、(vi)）。 □

定理 5.2 (Azuma–Hoeffding)**.** 假设 $A_k \le \xi_k \le A_k + c_k$，其中 A_k 可预测、c_k 为常数。则对每个 $u > 0$，

$$\mathbb{P}(M_n - M_0 \ge u) \le \exp\left(-\frac{2u^2}{\sum_{k\le n} c_k^2}\right),$$

且 $\mathbb{P}(M_n - M_0 \le -u)$ 有相同的界。

证明. 由规则 (ii)–(iv) 和引理 5.1，

$$\begin{aligned}\mathbb{E}e^{\lambda(M_n - M_0)} &= \mathbb{E}[e^{\lambda(M_{n-1}-M_0)}\mathbb{E}_{n-1}e^{\lambda\xi_n}] \\ &\le e^{\lambda^2 c_n^2/8}\mathbb{E}e^{\lambda(M_{n-1}-M_0)} \le \cdots \le \exp\left(\frac{\lambda^2}{8}\sum_{k\le n}c_k^2\right).\end{aligned}$$

对 Chernoff 界 $\mathbb{P}(M_n - M_0 \ge u) \le e^{-\lambda u}\mathbb{E}e^{\lambda(M_n-M_0)}$ 取 $\lambda = 4u/\sum c_k^2$，得到结论；对 $-M$ 应用即可得下尾界。 □

对简单随机游走，$\mathbb{P}(S_n \ge u) \le e^{-u^2/(2n)}$。

5.2 McDiarmid 不等式

定理 5.3 (有界差分)**.** 设 $Y_1,\dots,Y_N$ 独立，f 有界，且对所有参数和所有 k，

$$|f(y_1,\dots,y_N) - f(y_1,\dots,y_{k-1},y_k',y_{k+1},\dots,y_N)| \le c_k.$$

则对每个 $u>0$，

$$\mathbb{P}(f(Y) - \mathbb{E}f(Y) \ge u) \le \exp\left(-\frac{2u^2}{\sum_{k\le N} c_k^2}\right),$$

下尾有同样的界。

证明. 令 $M_k = \mathbb{E}_k f$ 为 Doob 鞅。由冻结引理，$M_k = g_k(Y_1,\dots,Y_k)$，其中 $g_k(y_1,\dots,y_k) = \mathbb{E}f(y_1,\dots,y_k,Y_{k+1},\dots,Y_N)$；当参数只在第 k 位不同时，$|g_k(\dots,y,\dots) - g_k(\dots,y',\dots)| \le c_k$。因此给定 $Y_1,\dots,Y_{k-1}$ 时，差分 $\xi_k = g_k(Y_1,\dots,Y_k) - g_{k-1}(Y_1,\dots,Y_{k-1})$ 位于 $[A_k, A_k + c_k]$，其中

$$A_k = \inf_y g_k(Y_1,\dots,Y_{k-1},y) - g_{k-1}(Y_1,\dots,Y_{k-1})$$

可预测。对 $M_N - M_0 = f - \mathbb{E}f$ 应用定理 5.2。 □

例 5.4 (Hoeffding 不等式)**.** 对 $f = n^{-1}\sum_{i\le n} Y_i$，其中 $Y_i \in [0,1]$，$c_i = 1/n$，且 $\mathbb{P}(\overline{Y}_n - \mathbb{E}\overline{Y}_n \ge u) \le e^{-2nu^2}$。

例 5.5 (泛化差距)**. 课堂演算**。设 $z_1,\dots,z_n$ 独立同分布，$\mathcal{H}$ 为预测器类，$\ell(h,z)\in[0,1]$ 为损失，$L(h) = \mathbb{E}\ell(h,z)$、$\widehat{L}_n(h) = n^{-1}\sum_i \ell(h,z_i)$，并令

$$Z = \sup_{h\in\mathcal{H}} (L(h) - \widehat{L}_n(h)).$$

改变一个 z_i 使每个 $\widehat{L}_n(h)$，从而 Z，改变至多 $1/n$。对任意类别 $\mathcal{H}$，定理 5.3 给出 $\mathbb{P}(Z \ge \mathbb{E}Z + u) \le e^{-2nu^2}$。

命题 5.6 (对称化)**.** 设 $\epsilon_1,\dots,\epsilon_n$ 为相互独立、与数据独立的均匀随机符号，则

$$\mathbb{E}Z \le 2\mathbb{E}\sup_{h\in\mathcal{H}} \frac{1}{n}\sum_{i\le n} \epsilon_i \ell(h,z_i).$$

证明. 令 $z_1',\dots,z_n'$ 为数据的独立副本，$\mathbb{E}'$ 表示对副本取期望，则 $L(h) = \mathbb{E}'\widehat{L}_n'(h)$。于是

$$\begin{aligned}\mathbb{E}Z &= \mathbb{E}\sup_h \mathbb{E}'[\widehat{L}_n'(h) - \widehat{L}_n(h)] \le \mathbb{E}\sup_h [\widehat{L}_n'(h) - \widehat{L}_n(h)] \\ &= \mathbb{E}\sup_h \frac{1}{n}\sum_i (\ell(h,z_i') - \ell(h,z_i)).\end{aligned}$$

对每个 i，由于 z_i, z_i' 可交换，将第 i 项乘以 ϵ_i 不改变整个族 $(\ell(h,z_i') - \ell(h,z_i))_{h,i}$ 的联合分布。故右侧等于 $\mathbb{E}\sup_h n^{-1}\sum_i \epsilon_i(\ell(h,z_i') - \ell(h,z_i))$，并至多为 $2\mathbb{E}\sup_h n^{-1}\sum_i \epsilon_i \ell(h,z_i)$。 □

推论 5.7 (有限类别)**.** 若 $|\mathcal{H}| = m$，则 $\mathbb{E}Z \le 2\sqrt{2\log m/n}$，从而 $\mathbb{P}(Z \ge 2\sqrt{2\log m/n} + u) \le e^{-2nu^2}$。

证明. 以数据为条件，$X_h = n^{-1}\sum_i \epsilon_i \ell(h, z_i)$ 满足 $\mathbb{E}e^{\lambda X_h} = \prod_i \cosh(\lambda \ell(h, z_i)/n) \le e^{\lambda^2/(2n)}$。第 9–11 讲命题 2.2 的证明只用此界，因此 $\mathbb{E}\max_h X_h \le \sqrt{2\log m/n}$。 □

对无限类别，命题 5.6 的右侧可如 Dudley 不等式那样用链化约束，以 Rademacher 过程代替高斯过程：链化约束上确界的均值，McDiarmid 不等式约束其涨落。

5.3 Ville 不等式

译注： 有限停时的极限先控制 “存在某时刻达到阈值”。对 $\{\sup_n Z_n \ge a\}$，须先对任意 $b < a$ 应用达到界，利用 $\{\sup_n Z_n \ge a\} \subset \{\exists n : Z_n \ge b\}$，再令 $b \uparrow a$，以包含只逼近而不达到 a 的路径。此为原证明的端点补充，定理仍有效。

命题 5.8 (Ville)**.** 设 Z 为非负上鞅。则对每个 $a > 0$，

$$\mathbb{P}\left(\sup_{n\ge 0} Z_n \ge a\right) \le \frac{\mathbb{E}Z_0}{a}.$$

证明. 令 $\tau = \min\{n : Z_n \ge a\}$。由推论 3.6 在有界时间 $\tau \wedge n$ 对上鞅 Z 的结论，以及非负性，

$$\mathbb{E}Z_0 \ge \mathbb{E}Z_{\tau\wedge n} \ge \mathbb{E}[Z_{\tau\wedge n}\mathbf{1}_{\{\tau\le n\}}] \ge a\mathbb{P}(\tau \le n).$$

令 $n \to \infty$。 □

初始值 $Z_0 = 1$ 的非负上鞅在某个时刻超过 a 的概率至多为 $1/a$，对所有停止规则一致成立；这就是序贯检验和置信序列背后的不等式。

5.4 Freedman 不等式

译注： 以下含 c 的除法取 $c > 0$；$c = 0$ 的退化 / 极限情形须分开。加权噪声例及习题的 $\eta_{\max} = \max_k \eta_k$ 形式要求非负且有界的可预测步长（确定性 SGD 步长足够）和相应可积性；一般有符号步长须用 $\sup_k |\eta_k|$。若步长依赖当前噪声则未必是鞅差，例如 $\eta_k = \xi_k = \pm 1$ 时乘积恒为 1。$\eta = 0$ 等含除法的退化情况也不直接代入。

引理 5.9. 令 $\psi_c(\lambda) = (e^{\lambda c} - 1 - \lambda c)/c^2$，$\lambda > 0$。若 $\mathbb{E}_{k-1}\xi = 0$、$\xi \le c$ 且 $\sigma^2 = \mathbb{E}_{k-1}\xi^2$，则

$$\mathbb{E}_{k-1}e^{\lambda\xi} \le 1 + \psi_c(\lambda)\sigma^2 \le \exp(\psi_c(\lambda)\sigma^2).$$

证明. $h(x) = (e^x - 1 - x)/x^2$（$h(0) = 1/2$）在 $\mathbb{R}$ 上递增（习题 5.14），故当 $x \le \lambda c$ 时，$e^x \le 1 + x + x^2 h(\lambda c)$。取 $x = \lambda\xi$ 并用 $\lambda^2 h(\lambda c) = \psi_c(\lambda)$，得 $e^{\lambda\xi} \le 1 + \lambda\xi + \psi_c(\lambda)\xi^2$；取 $\mathbb{E}_{k-1}$（规则 (vi)）。 □

推论 5.10. 设 $M_0 = 0$ 且对所有 k 有 $\xi_k \le c$。对每个 $\lambda > 0$，$Z_n = \exp(\lambda M_n - \psi_c(\lambda)\langle M\rangle_n)$ 是满足 $Z_0 = 1$ 的非负上鞅。

证明. $Z_n \le e^{\lambda nc}$ 有界，且 $\langle M\rangle_n$ 可预测，故由引理 5.9，$\mathbb{E}_{n-1}Z_n = Z_{n-1}e^{-\psi_c(\lambda)\sigma_n^2}\mathbb{E}_{n-1}e^{\lambda\xi_n} \le Z_{n-1}$。 □

定理 5.11 (Freedman 不等式)**.** 设 $M_0 = 0$ 且对所有 k 有 $\xi_k \le c$。则对所有 $u, v > 0$，

$$\mathbb{P}(\exists n : M_n \ge u \text{ 且} \langle M\rangle_n \le v) \le \exp\left(-\frac{u^2}{2(v + cu/3)}\right).$$

证明. 在该事件上，对相关的 n 有 $Z_n \ge \exp(\lambda u - \psi_c(\lambda)v)$，故由 Ville 不等式，

$$\mathbb{P}(\cdots) \le \mathbb{P}\left(\sup_n Z_n \ge e^{\lambda u - \psi_c(\lambda)v}\right) \le \exp(-\lambda u + \psi_c(\lambda)v).$$

对 $0 < \lambda < 3/c$，$\psi_c(\lambda) \le \lambda^2/[2(1 - \lambda c/3)]$（习题 5.14）。取 $\lambda = u/(v + cu/3) < 3/c$，则 $1 - \lambda c/3 = v/(v + cu/3)$，指数为

$$-\frac{u}{v + cu/3}u + \frac{u^2}{(v + cu/3)^2}\frac{v + cu/3}{2} = -\frac{u^2}{2(v + cu/3)}.$$

□

定理 5.11 相对定理 5.2 有两个区别：该界依赖于实现的二次变差 $\langle M\rangle_n$ 而非 $\sum c_k^2$（当 $v \gg cu$ 时为高斯尾 $e^{-u^2/(2v)}$；独立和的 Bernstein 不等式是确定性 σ_k^2 的情形），且它对所有 n 同时成立。

例 5.12 (依赖状态的噪声)**. 课堂演算**。令 $M_n = \sum_{k\le n}\eta_k\xi_k$，其中 $|\xi_k| \le c$，且对某个适应序列 (θ_k) 和满足 $s^2 \le c^2$ 的函数 s 有 $\sigma_k^2 = s^2(\theta_{k-1})$。Azuma 给出

$$\mathbb{P}(M_n \ge u) \le \exp\left[-\frac{u^2}{2c^2\sum_{k\le n}\eta_k^2}\right].$$

Freedman 对每个 v 给出

$$\mathbb{P}\left(\exists n : M_n \ge u,\ \sum_{k\le n}\eta_k^2 s^2(\theta_{k-1}) \le v\right) \le \exp\left(-\frac{u^2}{2(v + \eta_{\max}cu/3)}\right),$$

其中 $\eta_{\max} = \max_k \eta_k$。当路径 (θ_k) 将时间花在 s 小的区域时，v 可以取为远小于 $c^2\sum\eta_k^2$。对 SGD，这对应梯度噪声在极小点附近消失的区域（第 17 讲）。

引用 · 高斯集中不等式

设 $g \sim \mathcal{N}(0, I_d)$，$f : \mathbb{R}^d \to \mathbb{R}$ 对欧氏范数是 L-Lipschitz 的。则对所有 $u > 0$，$\mathbb{P}(f(g) - \mathbb{E}f(g) \ge u) \le e^{-u^2/(2L^2)}$。这是定理 5.3 的高斯对应物，用 L 代替 $(\sum c_k^2)^{1/2}$，且无需有界差分假设；它可用第 11 讲的插值法证明。

第 15 讲习题

习题 5.13 (A 类)**.** (a) 用常数 $e^{\lambda^2c^2/8}$ 证明引理 5.1：将 ξ 写成端点 $a, a + c$ 的凸组合得到 $\mathbb{E}e^{\lambda\xi} \le e^{\phi(\lambda c)}$，其中 $\phi(t) = -pt + \log(1 - p + pe^t)$、$p = -a/c$，并证明 $\phi(0) = \phi'(0) = 0$、$\phi'' \le 1/4$。

(b) 对 m 个固定预测器和 $[0,1]$ 中的损失，使用例 5.4 的并集界约束 $\mathbb{P}(\max_{j\le m}|\widehat{L}_n(h_j)-L(h_j)|\ge u)$，并与推论 5.7 比较。

习题 5.14 (A 类)**.** (a) 证明 $h(x)=(e^x-1-x)/x^2$ 在 $\mathbb{R}$ 上递增。令 $k(x)=x^3h'(x)=(x-2)e^x+x+2$；则 $k'(x)=(x-1)e^x+1$、$k''(x)=xe^x$，故 $k'\ge 0$，k 递增且 $k(0)=0$，并且在两条半直线上均有 $h'(x)=k(x)/x^3\ge 0$。

(b) 用 $k!\ge 2\cdot 3^{k-2}$，证明 $0<\lambda<3/c$ 时 $\psi_c(\lambda)\le \lambda^2/[2(1-\lambda c/3)]$。

习题 5.15 (线性预测器, B 类)**.** 设 $x_1,\dots,x_n\in\mathbb{R}^d$、$\|x_i\|\le B$，且 $\mathcal{H}=\{x\mapsto\langle w,x\rangle:\|w\|\le 1\}$。证明

$$\mathbb{E}\sup_{\|w\|\le 1}\frac{1}{n}\sum_i\epsilon_i\langle w,x_i\rangle=\frac{1}{n}\mathbb{E}\left\|\sum_i\epsilon_i x_i\right\|\le\frac{1}{n}\left(\sum_i\|x_i\|^2\right)^{1/2}\le\frac{B}{\sqrt{n}},$$

并与例 5.5 和命题 5.6 结合，得到不依赖于 d 的泛化界（可引用与 1-Lipschitz 损失复合不增加 Rademacher 复杂度）。

习题 5.16 (Robbins–Monro 噪声, B 类)**.** 设 $|\xi_k|\le c$、$\eta_k=\eta/k$。对 $m\ge 2$，令 $M_n=\sum_{k=m}^n\eta_k\xi_k$，$n\ge m$。

(a) 证明每步由 $\eta c/m$ 约束，且对所有 n 有 $\langle M\rangle_n\le\eta^2c^2/(m-1)$。

(b) 由定理 5.11 推得

$$\mathbb{P}\left(\exists n\ge m:\left|\sum_{k=m}^n\eta_k\xi_k\right|\ge u\right)\le 2\exp\left[-\frac{u^2}{2(\eta^2c^2/(m-1)+\eta cu/(3m))}\right].$$

(c) 与定理 3.10(ii) 比较。

习题 5.17 (有界差分的两个例子，B 类)**.** (a) 令 L_n 为 $[0,1]$ 中 n 个独立同分布均匀点的最长递增子序列长度。证明 L_n 的有界差分为 1，故 $\mathbb{P}(|L_n-\mathbb{E}L_n|\ge u)\le 2e^{-2u^2/n}$。（已知 $\mathbb{E}L_n\sim 2\sqrt{n}$，且涨落为 $n^{1/6}$ 量级。）

(b) 令 B_n 为将 n 个独立同分布、取值于 $[0,1]$ 的大小装箱所需的最少单位箱数。证明 B_n 的有界差分为 1，并证明 $\sqrt{n}$ 量级的涨落确实会发生（将 B_n 与各大小之和比较）。

习题 5.18 (SGD 中 Freedman 与 Azuma 的比较，C 类)**.** 在习题 2.12 中取 $\eta_k=\eta/k$、$\eta>1/2$，以及依赖状态的噪声 $\epsilon_{k+1}=s(\theta_k)\zeta_{k+1}$，其中 ζ_k 为独立同分布的随机符号，$s(\theta)=\min(|\theta|,1)$。

(a) 证明对固定 n，噪声项

$$N_n=\sum_{k<n}w_{n,k}s(\theta_k)\zeta_{k+1}$$

是某个鞅的末值，其二次变差为 $\sum_{k<n}w_{n,k}^2s(\theta_k)^2$。

(b) 写出 $\mathbb{P}(|N_n|\ge u)$ 的 Azuma 和 Freedman 界。

(c) 证明在事件 $\{|\theta_k| \le \delta \text{ 对} k \ge n/2\}$ 上，Freedman 的方差项比 Azuma 的小一个 δ^2 量级的因子，并建立一个关于 $\theta_n \to 0$ 速率的自举论证。

译注： 原文该事件仅约束后半段状态；二次变差仍含早期项，仅凭此事件不能直接对整个和得到所述 δ^2 因子，还需控制早期贡献。此处保留原习题要求，不补造证明。

(d) 模拟并比较。

习题 5.19 (算子范数，C 类)**.** 设 M 为元素独立的 $N \times d$ 矩阵。

(a) 若元素位于 $[-1,1]$，证明 $\|M\|_{\mathrm{op}}$ 对每个元素的有界差分为 2，故 $\mathbb{P}(\|M\|_{\mathrm{op}} - \mathbb{E}\|M\|_{\mathrm{op}} \ge u) \le e^{-u^2/(2Nd)}$。将尺度 $\sqrt{Nd}$ 与 $\mathbb{E}\|M\|_{\mathrm{op}} \asymp \sqrt{N} + \sqrt{d}$（第 9–11 讲）比较，并检验按行分组元素给出相同尺度。

译注： 有界差分界成立，但仅独立且在 $[-1,1]$ 内，不能保证期望算子范数为 $\sqrt{N}+\sqrt{d}$ 量级。元素恒为 1 也独立，此时范数为 $\sqrt{Nd}$；恒为 0 则范数为 0。该均值尺度需另有中心化、非退化方差及合适系综假设，不能从本题有界性单独推出。

(b) 若元素独立同分布于 $\mathcal{N}(0,1)$，证明 $M \mapsto \|M\|_{\mathrm{op}}$ 关于 Frobenius 范数是 1-Lipschitz 的，并结合高斯集中方框及 $\mathbb{E}\|M\|_{\mathrm{op}} \le \sqrt{N} + \sqrt{d}$（第 11 讲），得到 $\mathbb{P}(\|M\|_{\mathrm{op}} \ge \sqrt{N} + \sqrt{d} + u) \le e^{-u^2/2}$。

(c) (b) 利用了 $\|\cdot\|_{\mathrm{op}}$ 的什么性质，而有界差分无法表达这一性质？（Talagrand 凸距离不等式是有界变量中能表达它的结果。）



现代机器学习中的概率

ORF 526 课程材料译稿

手写课堂笔记（可得材料审校候选，待主控验收）

Fall 2026 课程资料 · 出版方未确认 · 2026
Model: gpt-6.1-sol；既有 gpt-6.1-terra；早期未知
审核：曹溪能
Updated: 2026-11-06

第 1 讲

本文件按手写 *PDF* 页序翻译。字迹或扫描边缘无法辨认之处明确标示；页号指原 *PDF*。

原 PDF 第 1 页

计划：I. Fourier；II. $\mathcal{N}(\mu,\Sigma)$ 的定义；III. 性质。

[课堂、作业和小测的安排；手写简记为 “diff class; HW+quiz”。] [bad $\mathcal{N}(\mu,\Sigma)$。]

定义。设 $f:\mathbb{R}^d\to\mathbb{R}$，则

$$\widehat{f}(\xi)=\int_{\mathbb{R}^d} e^{-ix\cdot\xi}f(x)\,dx,\qquad \xi\in\mathbb{R}^d.$$

性质。

(1) $f(x)=\int_{\mathbb{R}^d} e^{ix\cdot\xi}\widehat{f}(\xi)\,d\xi/(2\pi)^d$。

(2) $\widehat{\partial_{x_j}f}(\xi)=i\xi_j\widehat{f}(\xi)$。

(3) 原页写出 $\langle f,g\rangle_{L^2}=\int_{\mathbb{R}^d} f(x)g(x)\,dx=\int_{\mathbb{R}^d}\widehat{f}(\xi)\widehat{g}(\xi)\,d\xi=\langle\widehat{f},\widehat{g}\rangle_{L^2}$；右侧末端被扫描边缘截断。[1]

(4) 若 μ,ν 是概率分布，$\widehat{\mu}=\widehat{\nu}\Rightarrow\mu=\nu$。

定义。设 $X\sim\nu$ 是 $\mathbb{R}^d$ 中随机向量。X 在 ξ 处的特征函数为

$$\varphi_X(\xi)=\mathbb{E}[e^{-iX\cdot\xi}]=\int_{\mathbb{R}^d} e^{-ix\cdot\xi}\nu(x)\,dx=\widehat{\nu}(\xi).$$

原 PDF 第 2–4 页

定义。令 $\mu\in\mathbb{R}^d$、$\Sigma\in\mathrm{Sym}_{\geq 0}(d)$。若

$$\varphi_X(\xi)=\exp\{-i\mu\cdot\xi-\tfrac{1}{2}\xi^{\top}\Sigma\xi\},$$

则 $X\sim\mathcal{N}(\mu,\Sigma)$。[注意：$\Sigma$ 可以退化！]

性质。令 $X=(X_1,\dots,X_d)$。

(1) $\mathbb{E}[X_j]=\mu_j$。

(2) $\mathbb{E}[(X_j-\mu_j)(X_i-\mu_i)]=\Sigma_{ij}$。

(3) 若 $A\in\mathbb{R}^{m\times d}$、$b\in\mathbb{R}^m$，则 $AX+b\sim\mathcal{N}(A\mu+b,A\Sigma A^{\top})$。

(4) 若 $X\sim\mathcal{N}(0,I_d)$ 且 $O\in O(d)$，则 $OX\overset{d}{=}X$。

(5) $X\sim\mathcal{N}(\mu,\Sigma)$ 当且仅当对所有 v，$v\cdot X\sim\mathcal{N}(v^{\top}\mu,v^{\top}\Sigma v)$。

---

[1] 原式保留，右缘未辨部分不补造。依本页变换约定，例如对 Schwartz 函数，正确 Parseval 关系为 $\int f\overline{g}=(2\pi)^{-d}\int\widehat{f}\,\overline{\widehat{g}}$。即使 f,g 为实函数，频域也需共轭和归一化因子；一般函数的变换 / 反演还需相应可积性或正则性。

(6) 若 $Z=(X,Y)\sim\mathcal{N}(\mu,\Sigma)$ 且 $\mathbb{E}[XY^\top]=0$，则 X,Y 独立。[2]

证明。

(1)

$$\mathbb{E}[X_j]=\mathbb{E}\left[i\,\partial_{\xi_j}\big|_{\xi=0}\,e^{-iX\cdot\xi}\right]=i\,\partial_{\xi_j}\big|_{\xi=0}\,e^{-i\mu\cdot\xi-\xi^\top\Sigma\xi/2}=\mu_j.$$

(2)

$$\begin{aligned}\mathbb{E}[X_iX_j]&=-\mathbb{E}\left[\partial_{\xi_i}\partial_{\xi_j}\big|_{\xi=0}\,e^{-iX\cdot\xi}\right]\\&=-\,\partial_{\xi_i}\big|_{\xi=0}\left[\{-i\mu_j-(\Sigma\xi)_j\}e^{-i\mu\cdot\xi-\xi^\top\Sigma\xi/2}\right]=\Sigma_{ij}+\mu_i\mu_j.\end{aligned}$$

(3)

$$\begin{aligned}\mathbb{E}[e^{-i(AX+b)\cdot\xi}]&=\mathbb{E}[e^{-iX\cdot(A^\top\xi)}]e^{-ib\cdot\xi}\\&=e^{-i\mu\cdot A^\top\xi-\frac12(A^\top\xi)^\top\Sigma A^\top\xi-ib\cdot\xi}\\&=e^{-i(A\mu+b)\cdot\xi-\frac12\xi^\top(A\Sigma A^\top)\xi}.\end{aligned}$$

(4)

$$\mathbb{E}[e^{-i(OX)\cdot\xi}]=\mathbb{E}[e^{-iX\cdot(O^\top\xi)}]=e^{-\frac12(O^\top\xi)^\top IO^\top\xi}=e^{-\|\xi\|^2/2}.$$

(5) 显然!

(6) 写

$$\Sigma=\mathbb{E}[ZZ^\top]=\mathbb{E}[(X,Y)(X,Y)^\top]=\begin{pmatrix}\Sigma_{XX}&\Sigma_{XY}\\\Sigma_{XY}^\top&\Sigma_{YY}\end{pmatrix}.$$

$\mathbb{E}[XY^\top]=\Sigma_{XY}=0$，所以

$$\begin{aligned}\varphi_Z\begin{pmatrix}\xi_X\\\xi_Y\end{pmatrix}&=\exp\left[-i\begin{pmatrix}\mu_X\\\mu_Y\end{pmatrix}\cdot\begin{pmatrix}\xi_X\\\xi_Y\end{pmatrix}-\tfrac12\begin{pmatrix}\xi_X\\\xi_Y\end{pmatrix}^\top\begin{pmatrix}\Sigma_{XX}&0\\0&\Sigma_{YY}\end{pmatrix}\begin{pmatrix}\xi_X\\\xi_Y\end{pmatrix}\right]\\&=\varphi_X(\xi_X)\varphi_Y(\xi_Y).\end{aligned}$$

原 PDF 第 5 页：存在性

$d=1$：定义 $\nu(x)=e^{-x^2/2}/\sqrt{2\pi}$。若 $X\sim\nu$，则

$$\begin{aligned}\frac{d}{d\xi}\varphi_X(\xi)&=\frac{d}{d\xi}\int_{\mathbb{R}}e^{-ix\xi}\frac{e^{-x^2/2}}{\sqrt{2\pi}}\,dx\\&=\int_{\mathbb{R}}(-ixe^{-x^2/2})e^{-ix\xi}\frac{dx}{\sqrt{2\pi}}\\&=\int_{\mathbb{R}}(i\partial_xe^{-x^2/2})e^{-ix\xi}\frac{dx}{\sqrt{2\pi}}\\&=\int_{\mathbb{R}}e^{-x^2/2}(-i\partial_x)e^{-ix\xi}\frac{dx}{\sqrt{2\pi}}=-\xi\varphi_X(\xi).\end{aligned}$$

[2]原文保留。联合高斯独立性的正确条件是 $\mathrm{Cov}(X,Y)=0$；只有中心化时才能直接用 $\mathbb{E}[XY^\top]=0$。例如均值 $(1,-1)$、协方差 $\left(\begin{smallmatrix}1&1\\1&1\end{smallmatrix}\right)$ 的联合高斯变量满足 $\mathbb{E}[XY]=0$，但协方差为 1 且完全相关。

故 $\varphi_X(\xi) = e^{-\xi^2/2}$，其中 $\varphi_X(0) = 1$。

$d \geq 1$：令 $\nu_d(x) = \prod_{i=1}^d \nu(x_i)$。若 $X \sim \nu_d$，则

$$\varphi_X(\xi) = \prod_{i=1}^d \varphi_{X_i}(\xi_i) = e^{-\|\xi\|^2/2} \quad \Longrightarrow \quad X \sim \mathcal{N}(0, I).$$

原 PDF 第 6 页：例子

设 $X \sim \mathcal{N}(0,1)$。

(1) $Y = (X, X) \in \mathbb{R}^2$。问：$Y$ 是高斯的吗？答：是。$Y = \begin{pmatrix}1\\1\end{pmatrix} X$，故 $Y \sim \mathcal{N}(0, \begin{pmatrix}1 & 1\\1 & 1\end{pmatrix})$。

(2) 令 $Y = \epsilon X$，其中 $\epsilon \in \{\pm 1\}$ 独立于 X（原文在此还写有 “iid”）。问题 1：Y 是高斯的吗？问题 2：$Z = (X, Y)$ 是高斯的吗？

回答问题 1：是。因为

$$\begin{aligned}\mathbb{E}[e^{-iY\xi}] &= \mathbb{E}[e^{-iX(\epsilon\xi)}] = \mathbb{E}_\epsilon\left[\mathbb{E}_X[e^{-iX(\epsilon\xi)}]\right] \\ &= \mathbb{E}_\epsilon[e^{-(\epsilon\xi)^2/2}] = e^{-\xi^2/2}.\end{aligned}$$

原页在此结束；问题 2 在此页未给出回答。

第 2 讲

计划：I. 回顾；II. 条件期望＝投影；III. 高斯条件化＝线性；IV. 贝叶斯推断。

原 PDF 第 7 页

I. 回顾。令 $\mu \in \mathbb{R}^d$、$\Sigma \in \mathrm{Sym}_{\geq 0}(d)$，则

$$\begin{aligned}X \sim \mathcal{N}(\mu, \Sigma) \iff \mathbb{E}[e^{-i\xi\cdot X}] &= e^{-i\mu\cdot\xi - \frac{1}{2}\xi^\top \Sigma \xi}, \\ \mathbb{E}[X_i] = \mu_i, \qquad \mathrm{Cov}(X_i, X_j) &= \Sigma_{ij}.\end{aligned}$$

II. 假设 $(X, Y) \in \mathbb{R}^{1+m} \sim \nu$。问：给定 Y，对 X 的最佳猜测是什么？

预备。设 $Z \in \mathbb{R}^k$、$Z \sim \nu$ 且 $\mathbb{E}[f(Z)^2] < \infty$。

引理。$\mathbb{E}[f(Z)] = \mathrm{argmin}_c\, \mathbb{E}[(f(Z) - c)^2]$。

证明。原文写

$$\frac{d}{dc}\mathbb{E}[(f(Z) - c)^2] = 2\mathbb{E}[f(Z) - c]. \qquad \text{(原文)}$$

译注：正确导数为 $-2\mathbb{E}[f(Z) - c]$，原式漏了负号；令导数为 0 得到的临界点 $c = \mathbb{E}f(Z)$ 不变。□

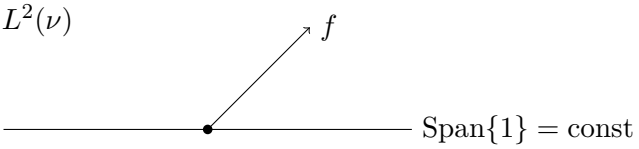
解释。(1) $\mathbb{E}[f(Z)]$ 是对 $f(Z)$ 的最佳确定性均方误差猜测。

原 PDF 第 8 页

（2）定义

$$L^2(\nu) = \{f : \mathbb{R}^k \to \mathbb{R} \mid \mathbb{E}[f(Z)^2] < \infty\},$$
$$\langle f, g\rangle_{L^2(\nu)} = \mathbb{E}[f(Z)g(Z)] = \int_{\mathbb{R}^k} f(z)g(z)\, d\nu(z).$$

原图示意 $L^2(\nu)$ 中常数子空间及向量 f：



$$\mathbb{E}[(f(Z) - c)^2] = \|f - c\|^2_{L^2(\nu)},$$
$$\mathbb{E}[f(Z)] = \inf_{c \in \mathrm{Span}\{1\}} \|f - c\|^2 = \Pi_{\mathrm{const}} f. \qquad \text{（原文）}$$

译注： 原式保留，但三者类型不同：$\operatorname{argmin}_c \|f - c\|^2 = \mathbb{E}f$，最小值 $\inf_c \|f - c\|^2 = \mathrm{Var}(f)$，而常数投影是 $(\mathbb{E}f)\mathbf{1}$。

主要内容。**定义**。设 $Z = (X, Y) \in \mathbb{R}^{1+m} \sim \nu$，$\mathbb{E}\|Z\|^2 < \infty$，且 $Y \sim \nu_Y$。则

$$\mathbb{E}[X \mid Y] = \operatorname*{argmin}_{g \in L^2(\nu_Y)} \mathbb{E}[(X - g(Y))^2] = X \text{ 在 } L^2(\nu_Y) \text{ 上的投影.}$$

原 PDF 第 9 页

性质。

(i) 对所有 g，$\mathbb{E}[(X - \mathbb{E}[X \mid Y])g(Y)] = 0$。

(ii) 若 $Z = (X, Y, V)$，则 $\mathbb{E}[X \mid Y] = \mathbb{E}[\mathbb{E}[X \mid Y, V] \mid Y]$（塔式性质）。

(iii) $\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}[X]$。

(iv) $\mathrm{Var}[X] = \mathbb{E}[\mathrm{Var}(X \mid Y)] + \mathrm{Var}[\mathbb{E}(X \mid Y)]$。

证明。(i) 显然。(ii) $L^2(\nu_Y) \subseteq L^2(\nu_{Y,V})$，故 $\Pi_Y = \Pi_Y \Pi_{Y,V}$。(iii) $Y = \mathrm{const}$。(iv) 配方。

III. 假设 $(X, Y) \in \mathbb{R}^{p+m} \sim \mathcal{N}(0, \Sigma)$，

$$\Sigma = \mathbb{E}[(X, Y)(X, Y)^\top] = \begin{pmatrix} \mathbb{E}[XX^\top] & \mathbb{E}[XY^\top] \\ \mathbb{E}[YX^\top] & \mathbb{E}[YY^\top] \end{pmatrix} = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}.$$

问：$\mathbb{E}[X \mid Y]$ 是什么?

原 PDF 第 10–11 页

引理。存在 A 使 $A\Sigma_{YY}=\Sigma_{XY}$。

证明。原页经涂改后的思路是

$$\begin{aligned}\Sigma_{YY}A^\top=\Sigma_{YX} &\iff \mathrm{Col}(\Sigma_{YY})\supseteq\mathrm{Col}(\Sigma_{YX})\\ &\iff \ker(\Sigma_{YY})^\perp\supseteq\mathrm{Col}(\Sigma_{YX})\\ &\iff \ker(\Sigma_{YY})\subseteq\mathrm{Col}(\Sigma_{YX})^\perp=\mathrm{Span}\{\mathbb{E}[YX_i]\}^\perp.\end{aligned}$$

取 $v\in\ker(\Sigma_{YY})$，则

$$0=v^\top\Sigma_{YY}v=\mathbb{E}[(Y\cdot v)^2]\Longrightarrow Y\cdot v=0\Longrightarrow v\cdot\mathbb{E}[YX_i]=0\ \forall i\Longrightarrow v\in\mathrm{Col}(\Sigma_{YX})^\perp.\qquad\square$$

定理。原文写

$$\mathbb{E}[X\mid Y]=AY\sim\mathcal{N}(0,\Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}).$$

译注： 普通逆形式要求 Σ_{YY} 可逆。若奇异，仍可取任意满足 $A\Sigma_{YY}=\Sigma_{XY}$ 的 A；A 未必唯一，但 AY 几乎必然唯一，条件期望依然有意义。原式保留，不将普通逆默换成广义逆。

证明。$\mathbb{E}[X\mid Y]$ 由对所有 $g\in L^2(\nu_Y)$ 的 $\mathbb{E}[(X-\mathbb{E}[X\mid Y])g(Y)]=0$ 定义。思路：若 $X-\mathbb{E}[X\mid Y]$ 独立于 Y，则完成。只需有

$$\mathrm{Cov}(X-\mathbb{E}[X\mid Y],Y)=0,\qquad (X-\mathbb{E}[X\mid Y],Y)\text{ 联合高斯.}$$

只需有 $\mathbb{E}[X\mid Y]=AY$。协方差约束给出

$$\mathrm{Cov}(X-AY,Y)=\mathrm{Cov}(X,Y)-\mathrm{Cov}(AY,Y)=\Sigma_{XY}-A\Sigma_{YY}.\qquad\square$$

IV. 假设观测到 $y=Hw+\sigma\epsilon$，其中 H 为 $n\times p$ 数据矩阵，w 为 $p\times 1$ 未知参数，$\epsilon\sim\mathcal{N}(0,I)$；先验为 $w\sim\mathcal{N}(0,\tau^2I)$。若 H 固定，则 $(\epsilon,y,w)\sim\mathcal{N}(0,\Sigma)$。

原 PDF 第 12 页

原文写

$$\Sigma=\begin{pmatrix}\Sigma_{yy}&\Sigma_{yw}&\Sigma_{y\epsilon}\\ &\Sigma_{ww}&\Sigma_{w\epsilon}\\ &&\Sigma_{\epsilon\epsilon}\end{pmatrix},$$

$$\begin{aligned}\Sigma_{yy}&=\tau^2HH^\top+\sigma^2I, & \Sigma_{w\epsilon}&=0,\\ \Sigma_{yw}&=\tau^2H^\top, & \Sigma_{y\epsilon}&=\sigma^2I,\\ \Sigma_{ww}&=\tau^2I, & \Sigma_{\epsilon\epsilon}&=I,\\ \mathbb{E}[w\mid y]&=(H^\top H+\lambda I)^{-1}H^\top y, & \mathrm{Cov}(w\mid y)&=\sigma^2(H^\top H+\lambda I)^{-1}.\end{aligned}$$

译注： 原块逐项保留。若 H 为 $n\times p$ 且 w,ϵ 独立，正确块为 $\mathrm{Cov}(y,w)=\tau^2H$（不是 $\tau^2H^\top$）、$\mathrm{Cov}(y,\epsilon)=\sigma I$（不是 σ^2I），并有 $\lambda=\sigma^2/\tau^2$。前文变量顺序 (ϵ,y,w) 与矩阵所排 (y,w,ϵ) 不同；下三角空白须作对称补全理解。密度 / 所示非退化逆形式通常取 $\sigma,\tau>0$，零参数另作极限或退化处理。

第 3 讲

计划：I. 中心极限定理陈述；II. 直观；III. Lindeberg 中心极限定理；IV. 高斯过程与神经网络。

原 PDF 第 13 页

I. 定义。设 X_n, X 为随机变量。若对所有有界连续函数 f，$\mathbb{E}[f(X_n)] \to \mathbb{E}[f(X)]$，则 $X_n \overset{d}{\Rightarrow} X$。

定理（中心极限定理）。设 X_i 独立同分布，$\mathbb{E}X_i = 0$、$\mathbb{E}X_i^2 = 1$，则当 $n \to \infty$，

$$S_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} X_i \overset{d}{\Rightarrow} Z \sim \mathcal{N}(0,1).$$

目标：以三种方式证明：Lindeberg（今天）、Lévy（作业）、Stein（周三）。

问：为什么是 $\mathcal{N}(0,1)$？直观上，对所有 n，$h(Z) \geq h(S_n)$（为什么?）。而 X, Y 独立同分布且对称时，$h(X) \leq h((X+Y)/\sqrt{2})$，故

$$S_{2^k} = \frac{1}{\sqrt{2}}(S_{2^{k-1}} + S'_{2^{k-1}}) \Longrightarrow h(S_{2^k}) \geq h(S_{2^{k-1}}).$$

原 PDF 第 14 页

译注： 前页熵讨论是启发式：CLT 允许离散变量，此时微分熵未定义；和差的熵单调论证另需对称性和有限 / 良定义的熵。单位有限方差且有密度时 $h \leq h(Z) < \infty$，仍可能为 $-\infty$。单调性本身不是 CLT 的证明。

II. 定理（Lindeberg）。假设 $\mathbb{E}|X_1|^3 < \infty$。则对每个 $f \in C^3(\mathbb{R})$ 且 $\|f'''\|_\infty < \infty$，原文写

$$|\mathbb{E}[f(S_n) - f(Z)]| \leq \frac{\|f'''\|_\infty}{6n^{3/2}}(\mathbb{E}|X_1|^3 + \mathbb{E}|Z|^3). \tag{原文}$$

译注： 原式保留。每项误差为 $O(n^{-3/2})$，共有 n 项，故全局界的分母应为 $6\sqrt{n}$，不是 $6n^{3/2}$。下方望远镜和 $\sum_k [f(S_n^{(k)}) - f(S_n^{(k-1)})]$ 等于 $f(Z) - f(S_n)$，与所印左端符号相反；后续绝对值估计不受该反号影响。

证明。对 $k = 0, \ldots, n$ 定义

$$S_n^{(k)} = \frac{1}{\sqrt{n}}(Z_1 + \cdots + Z_k + X_{k+1} + \cdots + X_n) = W_k + \frac{1}{\sqrt{n}} Z_k,$$
$$S_n^{(0)} = S_n, \qquad S_n^{(n)} = Z. \tag{原文}$$

于是原文写出望远镜式

$$f(S_n) - f(Z) = \sum_{k=1}^{n} \big(f(S_n^{(k)}) - f(S_n^{(k-1)})\big), \tag{原文}$$
$$|\mathbb{E}[f(S_n) - f(Z)]| \leq \sum_{k=1}^{n} \left|\mathbb{E}[f(S_n^{(k)}) - f(S_n^{(k-1)})]\right|.$$

逐项展开：

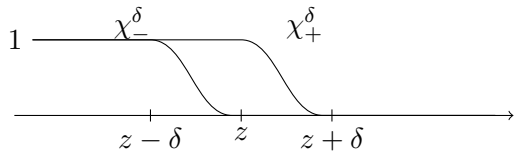
$$\begin{aligned}
&\left|\mathbb{E}\left[f\left(W_k+\frac{Z_k}{\sqrt{n}}\right)-f\left(W_k+\frac{X_k}{\sqrt{n}}\right)\right]\right| \\
&=\left|\mathbb{E}\left[f(W_k)+\frac{Z_k}{\sqrt{n}}f'(W_k)+\frac{Z_k^2}{2n}f''(W_k)+\frac{Z_k^3}{6n^{3/2}}f'''(\widetilde{W}_k)\right.\right. \\
&\qquad\left.\left.-\left(f(W_k)+\frac{X_k}{\sqrt{n}}f'(W_k)+\frac{X_k^2}{2n}f''(W_k)+\frac{X_k^3}{6n^{3/2}}f'''(\widehat{W}_k)\right)\right]\right| \\
&\le \frac{\|f'''\|_\infty}{6n^{3/2}}(\mathbb{E}|Z|^3+\mathbb{E}|X_i|^3). \qquad \square
\end{aligned}$$

原 PDF 第 15–16 页

记 $F_X(z)=\mathbb{P}(X\le z)$。

引理。若对所有 f, f', f'', f''' 有界的 f 有 $\mathbb{E}[f(X_n)]\to\mathbb{E}[f(X)]$，则对 F_X 连续的每个 z，$F_{X_n}(z)\to F_X(z)$。

证明。固定 z，注意 $F_X(z)=\lim_{\delta\downarrow 0}F_X(z-\delta)=\lim_{\delta\downarrow 0}F_X(z+\delta)$。原页图示两条光滑截断曲线 $\chi_-^\delta,\chi_+^\delta\in C^\infty$，分别在 $z-\delta$ 至 z 及 z 至 $z+\delta$ 之间从 1 降到 0。



注意

$$\mathbf{1}_{(-\infty,z-\delta]}\le\chi_-^\delta\le\mathbf{1}_{(-\infty,z]}\le\chi_+^\delta\le\mathbf{1}_{(-\infty,z+\delta]},$$

故

$$\mathbb{E}[\chi_-^\delta(X_n)]\le F_{X_n}(z)\le\mathbb{E}[\chi_+^\delta(X_n)].$$

原文继续写

$$\begin{aligned}
\mathbb{E}[\chi_-^\delta(X)]&\le\lim_{n\to\infty}F_{X_n}(z)\le\mathbb{E}[\chi_+^\delta(X)],\\
F_X(z-\delta)&\le\lim_{n\to\infty}F_{X_n}(z)\le F_X(z+\delta),\\
F_X(z)&=\lim_{n\to\infty}F_{X_n}(z). \qquad \square
\end{aligned}$$

译注：此处限值存在性是待证结论；用上、下极限可避免预设，原文照录。

Lindeberg / Feller 条件（更一般的中心极限定理）。令 $\{X_{i,n}\}_{i\le k_n}$ 为三角数组：

$$\begin{array}{ccc}
X_{1,1} & \cdots & X_{k_1,1},\\
X_{1,2} & \cdots & X_{k_2,2},\\
\vdots & &
\end{array}$$

对每个固定 n，$\{X_{i,n}\}_{i=1,\dots,k_n}$ 独立且中心化。写 $s_n^2=\sum_{i=1}^{k_n}\mathrm{Var}(X_{i,n})$。若对每个 $\epsilon>0$，

$$L_n(\epsilon)=\frac{1}{s_n^2}\sum_{i=1}^{k_n}\mathbb{E}[X_{i,n}^2\mathbf{1}_{\{|X_{i,n}|>\epsilon s_n\}}]\longrightarrow 0,$$

则该数组满足 Lindeberg 条件（LC）。

原 PDF 第 17 页

定理。（LC）$\Rightarrow s_n^{-1}\sum_{i=1}^{k_n}X_{i,n}\overset{d}{\Rightarrow}\mathcal{N}(0,1)$，$n\to\infty$。

再假设 Feller 条件（FC）：

$$\lim_{n\to\infty}\max_{1\le i\le k_n}\frac{\mathrm{Var}[X_{i,n}]}{s_n^2}=0.$$

定理。原文写（FC）且（LC）$\Longleftrightarrow$ CLT。[3]

定理（多维 CLT）。设 X_i 在 $\mathbb{R}^d$ 中独立同分布，$\mathbb{E}X_i=0$、$\mathbb{E}[X_iX_i^\top]=\Sigma$，且 $\mathbb{E}\|X_i\|^3<\infty$ 对所有 i 成立，则

$$S_n=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}X_i\overset{d}{\Rightarrow}\mathcal{N}(0,\Sigma).$$

证明：（思路?）

应用。令 $X_1,X_2,\dots$ 独立同分布，其分布 ν 有密度。设 $B_i=\mathbf{1}_{\{X_i>X_1,\dots,X_{i-1}\}}$。有 $\mathbb{P}(B_i=1)=1/i$，且 B_i 独立！

原 PDF 第 18 页

设 $R_n=\sum_{i\le n}B_i$。

定理。令 $H_n=\sum_{i=1}^{n}1/i$、$s_n^2=H_n-\sum_{i\le n}1/i^2$，则 $(R_n-H_n)/s_n\Rightarrow\mathcal{N}(0,1)$。

证明。（1）原文写：若 $|X_{n,i}|\le C$，Lindeberg 条件自动成立。[4]（2）令 $X_{n,i}=B_i-1/i$，则 $\mathbb{E}X_{n,i}=0$、$\mathrm{Var}(X_{n,i})=i^{-1}(1-i^{-1})$，故 $s_n^2=H_n-\sum_{i=1}^{n}1/i^2$。

引理。B_i 独立。

证明。令 $\rho_i=\#\{j\le i\mid X_j\le X_i\}$，即 X_i 在前 i 项中的秩，则 $B_i=\mathbf{1}_{\{\rho_i=i\}}$。注意 $(\rho_1,\dots,\rho_n)$ 与完整秩排列一一对应：$r_i=\#\{j\le n\mid X_j\le X_i\}$、$\rho_i=\#\{j\le i\mid X_j\le X_i\}$。$r_n\in S_n$ 均匀，且 r_n 与 $\rho=(\rho_1,\dots,\rho_n)$ 一一对应。 □

[原页另记："filler"：NNGP、Poisson。]

第 4 讲

计划：I. Stein 引理；II. 用 OU 方法证明中心极限定理；III. OU 入门；(IV. Poisson 极限)。

[3]正确作用域是：在 Feller 条件作为既定前提下，LC 当且仅当 CLT。若无此前提，把 "FC 且 LC" 与 CLT 无条件等同则不成立：每行仅一个标准高斯变量的阵列，归一化和始终标准高斯而 FC 失败。

[4]充分条件为 $C/s_n\to 0$，例如 $s_n\to\infty$；记录数例有 $s_n^2\sim\log n$，故满足。仅一致有界不够：每行一个 Rademacher 变量即不满足 LC。

原 PDF 第 19 页

I. 定理。令 $X_1, X_2, \dots$ 独立同分布，均值为 0、方差为 1，且 $\mathbb{E}|X_1|^3 < \infty$。对每个 h, h', h'', h''' 有界的 h，

$$|\mathbb{E}[h(S_n)] - \mathbb{E}[h(Z)]| \le \frac{\|h'''\|_\infty}{2\sqrt{n}} \mathbb{E}|X_1|^3.$$

目标：新的证明（并概述从 h''' 到 h'）。

引理 (Stein)。随机变量 $W \sim \mathcal{N}(0,1)$ 当且仅当对任何有界、绝对连续的 f，$\mathbb{E}[Wf(W)] = \mathbb{E}[f'(W)]$。

译注： 原检验函数表述还须保证两侧可积且分部积分合法，例如可使用有界 C^1 且导数有界的函数类。仅有界、绝对连续不能自动保证 $f'(G)$ 的高斯绝对可积性。

证明。设 $W \sim \mathcal{N}(0,1)$，则

$$\begin{aligned}\mathbb{E}[Wf(W)] &= \int w f(w) e^{-w^2/2} \frac{dw}{\sqrt{2\pi}} = \int f(w)(-\partial_w e^{-w^2/2}) \frac{dw}{\sqrt{2\pi}} \\ &= \int f'(w) e^{-w^2/2} \frac{dw}{\sqrt{2\pi}} = \mathbb{E}[f'(W)].\end{aligned}$$

原 PDF 第 20 页

反过来，取 $f(w) = e^{-iw\xi}$，则

$$-i\xi\varphi_W(\xi) = -i\varphi_W'(\xi) \quad \Longrightarrow \quad \varphi_W(\xi) = e^{-\xi^2/2}. \qquad \square$$

习题。对于 $f : \mathbb{R}^d \to \mathbb{R}$，$W \sim \mathcal{N}(0, \Sigma)$ 当且仅当 $\mathbb{E}[Wf(W)] = \Sigma\mathbb{E}[\nabla f(W)]$。

译注： 前式按原文保留。约定 $\varphi_W(\xi) = \mathbb{E}e^{-iW\xi}$ 时，$\mathbb{E}[We^{-iW\xi}] = i\varphi_W'(\xi)$，所以正确关系是 $-i\xi\varphi_W = i\varphi_W'$；原文右侧 $-i$ 的符号错误。修正后才得到 $\varphi_W' = -\xi\varphi_W$ 及所示高斯解。

解释。写 Stein 算子 $(\mathcal{A}f)(w) = f'(w) - wf(w)$，则 $W \sim \mathcal{N}(0,1)$ 当且仅当对所有 f，$\mathbb{E}[\mathcal{A}f(W)] = 0$。

II. 假设希望估计 $\mathbb{E}[h(W)] - \mathbb{E}[h(Z)]$，其中 $Z \sim \mathcal{N}(0,1)$。思路：对每个 $s \ge 0$ 定义

$$(T_s h)(w) \equiv \mathbb{E}_Z\left[h\left(e^{-s}w + \sqrt{1-e^{-2s}}\, Z\right)\right] \qquad (\text{OU 半群}).$$

问：$\lim_{s\to 0}(T_s h)(w)$ 是什么？答：$T_0 h = h$。问：$\lim_{s\to\infty}(T_s h)(w)$ 是什么？答：$\mathbb{E}_Z[h(Z)]$。

原 PDF 第 21 页

解释。T_s 通过“模糊” w，在恒等算子与高斯平均之间插值。

断言。$(T_s(T_t h))(w) = (T_{s+t}h)(w)$。

证明。

$$\begin{aligned}T_s(T_t h)(w) &= \mathbb{E}_Z[(T_t h)(e^{-s}w + \sqrt{1-e^{-2s}}\, Z)] \\ &= \mathbb{E}_{Z,Z'}\left[h\left(e^{-(t+s)}w + \sqrt{e^{-2t}-e^{-2(s+t)}}\, Z + \sqrt{1-e^{-2t}}\, Z'\right)\right] \\ &= \mathbb{E}_Z[h(e^{-(t+s)}w + \sqrt{1-e^{-2(s+t)}}\, Z)] = (T_{t+s}h)(w). \qquad \square\end{aligned}$$

定义。生成元 $\mathcal{L}u = \lim_{s\downarrow 0}(T_s u - u)/s$。

断言。$(\mathcal{L}u)(w) = u''(w) - wu'(w) = (\mathcal{A}u')(w)$。

证明。有

$$T_s u(w) - u(w) = \mathbb{E}_Z[u(e^{-s}w + \sqrt{1-e^{-2s}}\,Z) - u(w)].$$

原 PDF 第 22 页

原页继续用 $e^{-s} = 1 - s + O(s^2)$ 和 $1 - e^{-2s} = 2s + O(s^2)$ 展开；中间两处根号系数以及下式 u'' 前的系数被涂改，无法可靠确定，记作 c_{UNKNOWN}。保留局部图 ‘assets/handwritten-ambiguities/page22-generator.png‘。其可辨认部分写为

$$\begin{aligned} T_s u(w) - u(w) &= s\big(-wu'(w) + c_{\text{UNKNOWN}}u''(w)\big) + O(s^{3/2}),\\ \partial_s T_s &= \mathcal{L}T_s. \end{aligned}$$

III. 现希望估计 $|\mathbb{E}[h(S_n)] - \mathbb{E}[h(Z)]|$。原页将其与 $|T_0 h(S_n) - T_\infty h|$ 联系，但相关期望符号处有涂改。思路：寻找 f_h，使得

$$T_0 h(w) - T_\infty h(w) = f_h'(w) - w f_h(w) = \mathcal{A}f_h(w).$$

页底计算有划除，后续在下一页继续。

$$= \mathbb{E}_Z\Big[u\big((1-s)^{+o(s^2)}w + \sqrt{1-(1-2s+o(s^2))}\,Z\big) - u(w)\Big] \quad (4)$$

$$= \mathbb{E}_Z\Big[-s u'(w)\,(-sw + \sqrt{s}\,(1+o(s))Z) + \tfrac{1}{2}u''(w)(\sqrt{s})^2 Z^2 + o(s^{3/2})\Big]$$

$$= s\big(wu'(w) + u''(w)\big) + o(s^{3/2}) \qquad \square$$

原 PDF 第 22 页涂改系数局部；UNKNOWN 保持未决。

原 PDF 第 23 页

原文写

$$\begin{aligned} \mathcal{A}f_h = T_0 h - T_\infty h &= -\int_0^\infty \partial_s T_s h\,ds = -\mathcal{L}\int_0^\infty T_s h\,ds = -\mathcal{A}\left(\left(\int_0^\infty T_s h\,ds\right)'\right),\\ f_h(w) &= -\int_0^\infty \partial_w (T_s h)(w)\,ds\\ &= -\int_0^\infty e^{-s}\mathbb{E}[h'(e^{-s}w + \sqrt{1-e^{-2s}}\,Z)]\,ds. \end{aligned}$$

译注：原行保留；例如 $h\equiv 1$ 时 $\int_0^\infty T_s h\,ds=\infty$。势函数须积分 $T_sh-\mathbb{E}h(G)$ 的中心化量，并满足相应收敛条件；下方已经求导的 f_h 公式因含 e^{-s}，在 h' 有界时绝对收敛，不能把它与未中心化势积分的存在性混同。

有 $\|f\|_\infty\le\|h'\|_\infty$、$\|f'\|_\infty\le\|h''\|_\infty$、$\|f''\|_\infty\le\|h'''\|_\infty$。

现在可完成中心极限定理的证明。令 $W=S_n$，则

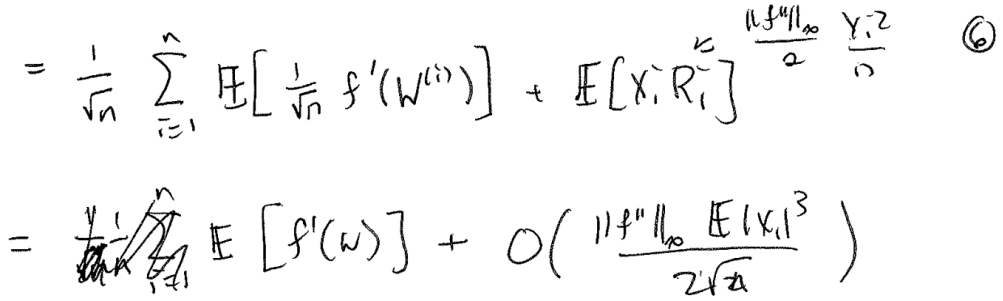
$$\mathbb{E}[Wf(W)]=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\mathbb{E}[X_i f(S_n)]=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\mathbb{E}\left[X_i f\left(W_i+\frac{X_i}{\sqrt{n}}\right)\right].$$

原 PDF 第 24 页

下一行及末行的可辨认部分如下；$\mathbb{E}[f'(W)]$ 前的系数被涂改，记作 c_{UNKNOWN}：

$$\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\left[\mathbb{E}\left(\frac{1}{\sqrt{n}}f'(W^{(i)})\right)+\mathbb{E}[X_iR_i]\right]=c_{\text{UNKNOWN}}\mathbb{E}[f'(W)]+O\left(\frac{\|f''\|_\infty\mathbb{E}|X_1|^3}{2\sqrt{n}}\right),$$

其中余项旁的手写界及末行求和系数有涂改，无法完整辨认，局部图为 ‘assets/handwritten-ambiguities/page24-final.png‘。本页到此结束。



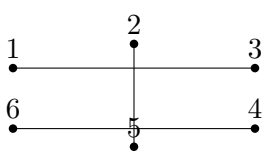
原 PDF 第 24 页末式局部；UNKNOWN 保持未决。

第 5 讲

计划：I. Wick；II. 累积量入门；III. GOE 定义；IV. GOE 的 Wick 公式。

原 PDF 第 25 页

定义。令 $k\ge 1$ 为偶数。$[k]=\{1,\dots,k\}$ 的配对划分是含 $k/2$ 个大小为 2 的块的划分 π。例如 $k=6$ 时 $\pi=\{(13),(25),(46)\}$，原图示意三个块：



定理（Wick）。设 $X=(X_1,\dots,X_d)\sim\mathcal{N}(0,\Sigma)$，则

$$\mathbb{E}[X_1\cdots X_d]=\sum_{\pi\in\mathrm{PP}(d)}\prod_{(i,j)\in\pi}\Sigma_{ij}.$$

证明。归纳法，$d=1,2$ 显然。[5]

$$\mathbb{E}[X_1\cdots X_d]=\left(\prod_{k=1}^{d}i\partial_{\xi_k}\right)\mathbb{E}[e^{-iX\cdot\xi}]\Big|_{\xi=0}.$$

原 PDF 第 26 页

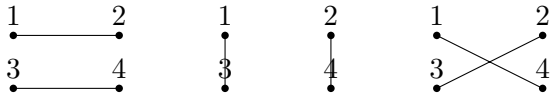
$$\begin{aligned}
&=\left(\prod_{k=1}^{d}i\partial_{\xi_k}\right)e^{-\xi^\top\Sigma\xi/2}\Big|_{\xi=0}\\
&=\left(\prod_{k=1}^{d-1}i\partial_{\xi_k}\right)\left[-i(\Sigma\xi)_d e^{-\xi^\top\Sigma\xi/2}\right]\Big|_{\xi=0}\\
&=\sum_{m=1}^{d-1}\Sigma_{md}\prod_{k\neq m,d}i\partial_{\xi_k}e^{-\xi^\top\Sigma\xi/2}\Big|_{\xi=0}\\
&=\sum_{m=1}^{d-1}\Sigma_{md}\sum_{\pi\in\mathrm{PP}([d]\setminus\{m,d\})}\prod_{(i,j)\in\pi}\Sigma_{ij}.\qquad\square
\end{aligned}$$

例 1。设 $X\sim\mathcal{N}(0,1)$。计算 $\mathbb{E}[X^q]$。令 $(X_1,\dots,X_q)$ 的每个坐标均为 X，其分布为 $\mathcal{N}(0,\mathbf{1}\mathbf{1}^\top)$，则

$$\mathbb{E}[X^q]=\mathbb{E}[X_1\cdots X_q]=\sum_{\pi\in\mathrm{PP}(q)}\prod_{(i,j)\in\pi}1=|\,\mathrm{PP}(q)|=\begin{cases}0, & q\text{ 为奇数},\\ (q-1)!!, & q\text{ 为偶数}.\end{cases}$$

原 PDF 第 27 页

例 2。写出 $\mathbb{E}[X_1X_2X_3X_4]$ 的“图”：



对应 $\Sigma_{12}\Sigma_{34}+\Sigma_{13}\Sigma_{24}+\Sigma_{14}\Sigma_{23}$。

例 3。原页写 $\mathrm{Var}[X^\top AX]=\sum_{ijk\ell}A_{ij}A_{k\ell}\mathbb{E}[X_iX_jX_kX_\ell]=2\,\mathrm{tr}((A\Sigma)^2)+(\mathrm{tr}(A\Sigma))^2$，但末项在右边被扫描边缘截断并有涂改。保留该页二次型局部图，数学疑点见 ISSUES。

译注：所示四阶矩和实际为 $\mathbb{E}[(X^\top AX)^2]$，不是方差。中心高斯 X 且 A 对称时，二阶矩为 $2\,\mathrm{tr}((A\Sigma)^2)+(\mathrm{tr}(A\Sigma))^2$，方差仅为 $2\,\mathrm{tr}((A\Sigma)^2)$；一般 A 须取其对称部分。$d=1,A=\Sigma=1$ 时原右侧为 3，而 $\mathrm{Var}(G^2)=2$。边缘截断及涂改仍不补造。

[5]手写注释为 “induction trivial $d=1,2$”。

背景与定义。设 $X=(X_1,\dots,X_d)$ 为具有所有有限矩的任意随机向量。其联合 / 混合累积量为

$$\kappa(X)\equiv\kappa(X_1,\dots,X_d)=\,i^m\frac{\partial^m}{\partial\xi_1\cdots\partial\xi_m}\log\mathbb{E}[e^{-i\xi\cdot X}]\Big|_{\xi=0}.$$

定理。有以下性质：

(0) $\kappa(X_1)=\mathbb{E}X_1$，$\kappa(X_1,X_2)=\operatorname{Cov}(X_1,X_2)$。

(i) $\kappa(\cdot,\dots,\cdot)$ 多线性。

(ii) $\kappa(X_1,\dots,X_d+c)=\kappa(X_1,\dots,X_d)+c\delta_{d,1}$。

(iii) 若 $[d]=\ell\cup\ell^c$，$\ell\neq\varnothing$、$\ell\neq[d]$，且 $X_\ell\perp X_{\ell^c}$，则 $\kappa(X)=0$。

(iv) $\mathbb{E}[X_1\cdots X_d]=\sum_{\pi\in\mathcal{P}(d),\,\pi=(\pi_1,\dots,\pi_B)}\prod_{b=1}^{B}\kappa(X_{\pi_b})$。

原 PDF 第 28 页

性质 (v) 为条件累积量的划分求和，左侧和求和号右侧被涂改，完整记号无法可靠辨认。局部图保存为 ‘assets/handwritten-ambiguities/page28-cumulant.png‘。

III. 定义（GOE）。令 $N\geq1$，取

$$M=\frac{1}{\sqrt{2}}(A+A^{\top}),\qquad A=(a_{ij}),\qquad a_{ij}\overset{\text{iid}}{\sim}\mathcal{N}(0,1/N).$$

即 $M=(m_{ij})$ 满足 $m_{ij}=m_{ji}$，原页接着写 $i\neq j$ 时 $m_{ij}\sim\mathcal{N}(0,1)$，$i=j$ 时 $m_{ij}\sim\mathcal{N}(0,2)$。[6]

目标：研究 $N\to\infty$ 时特征值 $\lambda_1=\lambda_1(M)\geq\cdots\geq\lambda_N=\lambda_N(M)$。注意

$$\mathbb{E}[M_{ij}M_{k\ell}]=\frac{1}{N}(\delta_{ik}\delta_{j\ell}+\delta_{i\ell}\delta_{jk}).$$

断言。固定 $u\in\mathbb{R}^N$，问 $\mathbb{E}\|Mu\|^2$ 是什么？

证明。原页开始计算

$$\mathbb{E}\|Mu\|^2=\mathbb{E}\left[\sum_{i=1}^{N}(Mu)_i^2\right]=\mathbb{E}\left[\sum_{i=1}^{N}\left(\sum_{j=1}^{N}M_{ij}u_j\right)^2\right].$$

原 PDF 第 29–30 页

第 29 页仅写下未完成的计算：

$$\frac{1}{N}\operatorname{tr}(M^2)=\frac{1}{N}\sum_{i=1}^{N}\mathbb{E}[(M^2)_{ii}]=\frac{1}{N}\sum_{i=1}^{N}\mathbb{E}\left[\sum_{j=1}^{N}M_{ij}M_{ji}\right].\qquad\text{(原文)}$$

左侧期望记号有涂改，暂按可见形式保留；未给出后续结论。第 30 页在 170 dpi 原页图上无正文，是空白页。

[6] 按上面构造，非对角元素方差实际为 $1/N$，对角为 $2/N$；原印的 1、2 少了 N 的归一化。源句保留。

第 6 讲

计划：I. 半圆定理；II. 预备；III. 路径=矩；IV. 证明。

原 PDF 第 31 页

回顾。 $M=(m_{ij})_{i,j=1,\dots,N}$，其中原页写

$$m_{ij}=\begin{cases}\mathcal{N}(0,1/N), & i>j,\\ \mathcal{N}(0,2/N), & i=j,\\ m_{ji}, & i<j.\end{cases}$$

定理（Wigner）。记 λ_i 为 M 的特征值。对所有 $a<b$,

$$\frac{1}{N}\#\{i\le N\mid a\le\lambda_i\le b\}\longrightarrow\int_a^b\rho_{\mathrm{sc}}(x)\,dx,$$

其中原页写

$$\rho_{\mathrm{sc}}(x)=\begin{cases}\sqrt{4-x^2}, & |x|\le 2,\\ 0, & \text{其他情形.}\end{cases}\qquad\text{(原文)}$$

译注： 原式保留；$\int_{-2}^{2}\sqrt{4-x^2}\,dx=2\pi$，所以概率密度还须因子 $1/(2\pi)$。源收敛箭头未说明模式，不据此补成几乎必然收敛。

证明思路。（1）若极限直方图 ρ 存在，则第 k 阶矩

$$\frac{1}{N}\sum_{i=1}^{N}\lambda_i^k\xrightarrow[N\to\infty]{}\int_{\mathbb{R}}x^k\rho(x)\,dx.$$

原 PDF 第 32 页

（2）计算 $N\to\infty$ 时

$$\mathbb{E}\left[\frac{1}{N}\sum_{i=1}^{N}\lambda_i^k\right]=\mathbb{E}\left[\frac{1}{N}\operatorname{tr}(M^k)\right]=\mathbb{E}[\text{高斯变量的多项式}]\longrightarrow m_k.$$

（3）检验

$$\frac{\operatorname{Var}[N^{-1}\sum_{i=1}^{N}\lambda_i^k]}{\left(\mathbb{E}[N^{-1}\sum_{i=1}^{N}\lambda_i^k]\right)^2}\longrightarrow 0.\qquad\text{(原文)}$$

译注： 奇数阶矩的期望为零，此比值一般未定义；见 ISSUES。

（4）找到满足 $\int x^k\,d\rho=m_k$ 的 $\rho=\rho_{\mathrm{sc}}$。

译注： 仅直方图 / 测度的弱收敛不能直接代入无界 x^k，还须一致可积性、尾部控制或直接矩估计。上述策略并未自动提供这些假设；奇数矩的零分母问题也须用绝对方差估计替代。

预备。$\mathbb{E}[M_{ab}M_{cd}] = N^{-1}(\delta_{ac}\delta_{bd} + \delta_{ad}\delta_{bc})$。于是

$$\mathbb{E}\left[\frac{1}{N}\operatorname{tr}(M^2)\right] = \frac{1}{N}\sum_{i=1}^{N}\mathbb{E}\left[\sum_{j=1}^{N} M_{ij}M_{ji}\right] = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}\frac{1}{N}(\delta_{ij}+1) = 1 + O(1/N),$$

$$\mathbb{E}\left[\frac{1}{N}\operatorname{tr}(M^4)\right] = \mathbb{E}\left[\frac{1}{N}\sum_{i=1}^{N}\sum_{a,b,c} m_{ia}m_{ab}m_{bc}m_{ci}\right].$$

原 PDF 第 33 页

上一式经三种配对展开为

$$\frac{1}{N^3}\sum_{i,a,b,c}\Big[(\delta_{ia}\delta_{ab}+\delta_{ib}\delta_{aa})(\delta_{bc}\delta_{ci}+\delta_{bi}\delta_{cc}) + (\delta_{ib}\delta_{ac}+\delta_{ic}\delta_{ab})(\delta_{ac}\delta_{bi}+\delta_{ai}\delta_{bc}) + (\delta_{ic}\delta_{ai}+\delta_{ii}\delta_{ac})(\delta_{ab}\delta_{bc}+\delta_{ac}\delta_{bb})\Big].$$

原页注明，配对 {12}{34} 贡献 δ_{ib} 加上两个或更多指标相等的项；{13}{24} 只产生两个或更多指标相等的项；{14}{23} 贡献 δ_{ac} 加上两个或更多指标相等的项。因此

$$\frac{1}{N^3}\sum_{i}\sum_{a,b,c}(\delta_{ib}+\delta_{ac}) + O(1/N) = 2 + O(1/N).$$

一般矩。回顾 $(AB)_{ij} = \sum_{\ell} a_{i\ell}b_{\ell j}$。原页接着把矩阵幂写为沿路径的乘积之和，部分上下标被涂改和扫描边缘截断；局部图为工程中的第 33 页路径图。可辨认内容是：构造图 $\mathcal{G} = (V = [N], \text{所有边})$，$m$ 步路径 $\pi = (\pi(0), \dots, \pi(m))$ 从 i 到 j，其权重为各步矩阵元的乘积。

译注：以下以 m 记可辨的路径步数，转写其可靠的结构；原幂次及个别指标的涂改字形仍不认定已复原：

$$(M^m)_{ij} = \sum_{\substack{\pi(0)=i,\ \pi(m)=j \\ \pi(1),\dots,\pi(m-1)\in[N]}} \prod_{a=1}^{m} M_{\pi(a-1),\pi(a)}.$$

Recall: $(AB)_{ij} = \sum_{\ell} a_{i\ell}b_{\ell j}$

$\Rightarrow (M^{2k})_{ij} = \sum_{i_2,\dots,i_{2k}} m_{ii_2}m_{i_2i_3}\cdots m_{i_{2k}i}$

Interp: Construct graph $\mathcal{G} = (V = [N], \text{all edges})$

$(M^m)_{ij} = \sum_{\text{paths of } m \text{ steps}} \prod_{a=2}^{m} m^{\omega(\pi)}_{\pi(a-1)\pi(a)}$

$\pi = (\pi(0), \dots, \pi(m))\quad \pi(0) = i\ \pi(m) = j$

原 PDF 第 33 页路径式局部；涂改指数及右边界仅以本图保留，不猜补原字形。

原 PDF 第 34 页

因此原页写

$$\mathbb{E}\left[\frac{1}{N}\operatorname{tr}(M^{2k})\right] = \frac{1}{N}\sum_{i=1}^{N}\mathbb{E}\left[\sum_{\substack{\pi:\,2k\ \text{步}\\ i\to i}}\omega(\pi)\right]$$

$$= \sum_{\substack{\pi:\,2k\ \text{步}\\ i\to i}}\mathbb{E}[\omega(\pi)], \qquad \omega(\pi)=\prod_{a=1}^{2k} m_{\pi(a-1),\pi(a)}, \tag{原文}$$

其中 $\pi=(i,\pi(1),\dots,\pi(2k-1),i)$。[7] **引理**。除非路径 π 访问每条边偶数次，否则 $\mathbb{E}[\omega(\pi)]=0$；并且 $|\mathbb{E}[\omega(\pi)]|\le \alpha_k N^{-k}$（常数附近有涂改）。

回到 $\mathbb{E}[N^{-1}\operatorname{tr}(M^2)]$，原页写

$$\frac{1}{N}\sum_{\pi=(i,\pi(1),i)}\mathbb{E}[m_{i\pi(1)}m_{\pi(1)i}]=1. \tag{原文}$$

译注： 此 GOE 归一化下，有限 N 的精确值为 $1+1/N$，不是恰好 1；N 个对角元素各方差 $2/N$ 贡献了该修正。原式保留。

原页下方有若干表示顶点的点状示意，未连接成完整图。

第 7 讲

计划：I. Stieltjes 入门；II. 两个重要思路；III. 通过 Stieltjes 变换求密度。

原 PDF 第 35 页

令 $M=(A+A^\top)/\sqrt{2}$，$A=(a_{ij})_{i,j=1,\dots,N}$，$a_{ij}\overset{\text{iid}}{\sim}\mathcal{N}(0,1/N)$。

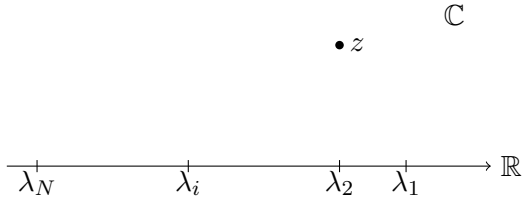
定理（原页写 Wigner、Marchenko–Pastur）。对 $a<b$，

$$\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}\xrightarrow[N\to\infty]{}\int_a^b \rho_{\text{sc}}(x)\,dx, \qquad \rho_{\text{sc}}(x)=\frac{1}{2\pi}\sqrt{4-x^2}\,\mathbf{1}_{\{|x|\le 2\}}.$$

目标：通过“Stieltjes 变换”给出新证明：

$$m_N(z)\equiv\frac{1}{N}\operatorname{tr}((M-zI)^{-1})=\frac{1}{N}\sum_{i=1}^{N}\frac{1}{\lambda_i-z}=\mathbb{E}_\lambda\left[\frac{1}{\lambda-z}\right].$$

原图在实轴上标出 $\lambda_N,\dots,\lambda_i,\dots,\lambda_2,\lambda_1$，并在复平面上标出 z。



[7] 第二行漏写 $1/N$ 及起点和；完整归一化结构应为 $\frac{1}{N}\sum_{i=1}^{N}\sum_{\pi:\,2k\ \text{步},\,i\to i}\mathbb{E}\omega(\pi)$。原行保留。

解释。(1) 当 $|z|\gg 1$,

$$(M-zI)^{-1}=-\frac{1}{z}\left(I-\frac{M}{z}\right)^{-1}=-\frac{1}{z}\sum_{k\geq 0}\frac{M^k}{z^k}.$$

原 PDF 第 36 页

于是 $m_N(z)=-z^{-1}\sum_{k\geq 0}z^{-k}N^{-1}\operatorname{tr}(M^k)=-1/z+O(|z|^{-2})$ ($|z|\to\infty$),它“编码了矩”。

译注：对固定有限矩阵，Neumann 级数需要 $|z|>\|M\|_{\mathrm{op}}$ 才收敛。原文 $|z|\gg 1$ 是固定 M 后足够大的简写，不能当作与矩阵无关的统一收敛域。

(2) $(\lambda-z)^{-1}$ 是“λ 处电子在 z 处产生的电场”，因此 $m_N(z)$ 是 λ_i 处电子在 z 处产生的总电场。

证明思路。对每个 N，原页写

$$\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}=\frac{1}{\pi}\int_a^b \operatorname{Im} m_N(x+i\epsilon)\,dx+O(\sqrt{\epsilon}).\qquad (*,\ \text{原文})$$

译注：对固定 N，端点 a 或 b 恰有特征值时，平滑积分极限给该原子一半质量，而开区间计数不含它，故误差未必为 $O(\sqrt{\epsilon})$。无端点特征值时可得到依赖谱隙的常数，仍不是统一于 N 的界。第 38 页采用先 $N\to\infty$、再 $\epsilon\downarrow 0$ 及极限虚部有界的估计，是不同次序；不能任意交换极限。留数轮廓须避开极点。

于是计数比例趋于 $\int_a^b \lim_{\epsilon\downarrow 0}\lim_{N\to\infty}\operatorname{Im} m_N(x+i\epsilon)\,dx$（原行积分前系数处有涂改）。此外，通过“空穴法” $m_N(z)\to m(z)$，且

$$m(z)=(-m(z)-z)^{-1}\quad\Longrightarrow\quad m(z)^2+zm(z)+1=0.$$

今天证明 $(*)$。

引理。$\|(M-zI)^{-1}\|=\max_i|\lambda_i-z|^{-1}\leq|\operatorname{Im} z|^{-1}$，故 $|m_N(z)|\leq|\operatorname{Im} z|^{-1}$。

引理（密度上界）。$N^{-1}\#\{i:|\lambda_i-a|\leq\eta\}\leq 2\eta\operatorname{Im} m_N(a+i\eta)$。

原 PDF 第 37 页

步骤 1。令 $\Gamma=\partial([a,b]\times[-\epsilon,\epsilon])$。原页写

$$\begin{aligned}\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}=\frac{1}{\pi}\int_a^b \operatorname{Im} m_N(x+i\epsilon)\,dx\\ +\frac{1}{N\pi}\sum_{i=1}^{N}\left[\arctan\frac{\epsilon}{\lambda_i-a}-\arctan\frac{\epsilon}{\lambda_i-b}\right].\end{aligned}$$

证明。原页由留数写

$$\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}=-\frac{1}{2\pi i}\oint_\Gamma m_N(z)\,dz.$$

译注：若端点恰为特征值，轮廓穿过极点；原页未说明排除或极限约定，见 ISSUES。

右侧分为水平边 A 和竖直边 B:

$$-\frac{1}{2\pi i}\left[\int_a^b(m_N(x-i\epsilon)-m_N(x+i\epsilon))\,dx+\int_{-\epsilon}^{\epsilon}(m_N(b+iy)-m_N(a+iy))i\,dy\right].$$

注意 $m_N(\bar z)=\overline{m_N(z)}$，故 $A=\int_a^b -2i\,\mathrm{Im}\,m_N(x+i\epsilon)\,dx$。再由

$$m_N(b+iy)=\frac{1}{N}\sum_{i=1}^{N}\frac{1}{(\lambda_i-b)-iy}=\frac{1}{N}\sum_{i=1}^{N}\frac{\lambda_i-b+iy}{(\lambda_i-b)^2+y^2},$$
$$\int_{-\epsilon}^{\epsilon} m_N(b+iy)i\,dy=\frac{1}{N}\sum_{i=1}^{N}2i\arctan\frac{\epsilon}{\lambda_i-b}.$$

由于 $|\arctan t|\le\min(\pi/2,|t|)$，得到下一页的估计。

原 PDF 第 38 页

令 $d_i=\min\{|\lambda_i-a|,|\lambda_i-b|\}$，则

$$\left|\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}-\frac{1}{\pi}\int_a^b \mathrm{Im}\,m_N(x+i\epsilon)dx\right|\le\frac{1}{N}\sum_{i=1}^{N}\min\left(1,\frac{2\epsilon}{\pi d_i}\right).\tag{\#}$$

因此对于 $\eta>0$，

$$\begin{aligned}(\#)&\le\frac{1}{N}\sum_i\min\left(1,\frac{2\epsilon}{\pi d_i}\right)(\mathbf{1}_{\{d_i\le\eta\}}+\mathbf{1}_{\{d_i>\eta\}})\\&\le\frac{\#\{i:d_i\le\eta\}}{N}+\frac{2\epsilon}{\pi\eta}\\&\le 2\eta\big(\mathrm{Im}\,m_N(a+i\eta)+\mathrm{Im}\,m_N(b+i\eta)\big)+\frac{2\epsilon}{\pi\eta}.\end{aligned}$$

原页随后假设存在 $m:\mathbb{H}\to\mathbb{R}$，$\mathrm{Im}\,m\le K$，$m(x)=\lim_{\epsilon\downarrow0}m(x+i\epsilon)$，并写在每个 L,ϵ 下 $\sup_{|x|\le L}|m_N(x+i\epsilon)-m(x+i\epsilon)|\to0$；期望及上确界附近有涂改。取 $\eta=\sqrt{\epsilon}$ 后原页给出极限期望误差至多 $C\sqrt{\epsilon}$，进而框出极限密度

$$\rho(x)=\lim_{\epsilon\downarrow0}\lim_{N\to\infty}\frac{1}{\pi}\mathrm{Im}\,m_N(x+i\epsilon).$$

原 PDF 第 39 页

现在目标是计算 $N\to\infty$ 时 $m_N(x+i\epsilon)$ 的极限；两步：期望和方差。

引理。设 $A=\begin{pmatrix}\alpha&\beta^\top\\\beta&\Delta\end{pmatrix}$，则

$$\gamma=(A^{-1})_{11}=(\alpha-\beta^\top\Delta^{-1}\beta)^{-1},\qquad \mathrm{tr}(A^{-1})=\mathrm{tr}(\Delta^{-1})+\gamma(1+\beta^\top\Delta^{-2}\beta).$$

原页注明“以后再证”。写 M 的左上元素为 M_{11}、其余第一行 / 列为 β、删去第一行列的矩阵为 $M^{(1)}$。目标是联系 $(M-zI)^{-1}$ 与 $R=(M^{(1)}-zI)^{-1}$，于是

$$((M-zI)^{-1})_{11}=\frac{1}{M_{11}-z-\beta^\top(M^{(1)}-zI)^{-1}\beta},$$
$$\mathbb{E}[m_N(z)]=\mathbb{E}[((M-zI)^{-1})_{11}]=\mathbb{E}\left[\frac{1}{M_{11}-z-\beta^\top(M^{(1)}-zI)^{-1}\beta}\right].$$

原页旁记其绝对值不超过 $1/|\operatorname{Im} z|$。观察：(1) $M_{11}=O(1/\sqrt{N})$；(2) $\beta\sim\mathcal{N}(0,N^{-1}I_{N-1})$，故原页写

$$\beta^{\top}(M^{(1)}-zI)^{-1}\beta=\frac{1}{N}\operatorname{tr}(M^{(1)}-zI)+O(1/\sqrt{N}). \qquad \text{(原文)}$$

译注： 正确中心应为 $N^{-1}\operatorname{tr}(M^{(1)}-zI)^{-1}=N^{-1}\operatorname{tr}R$；源右侧少了逆号。集中估计需 β 与子矩阵独立，并固定 $\operatorname{Im} z=\epsilon>0$；$O(N^{-1/2})$ 应按含 ϵ 常数的 L^2 / 概率随机阶理解，M_{11} 的阶也不是逐样本确定性界。原式保留。

原 PDF 第 40 页

原页尝试写 $M_{11}-z-\beta^{\top}R\beta=-z-\mathbb{E}[m_N]+\text{Error}$。误差定义及期望式被多处涂改，不能可靠逐项辨认；保存局部图 ‘assets/handwritten-ambiguities/page40-error.png‘。原页可辨认的后续结论为

$$m=\frac{1}{-z-m}\quad\Longrightarrow\quad m^2+zm+1=0,$$
$$m(z)=\frac{-z\pm\sqrt{z^2-4}}{2}.$$

原页写：只有加号给出正确边界。

译注： 加号公式须取上半平面上满足 $\sqrt{z^2-4}\sim z$（无穷远处）的解析支，使 $\operatorname{Im} m>0,|m|<1$。不是任取逐点主平方根；例如 z 接近 $-3+i0$ 时，所需平方根实部为负，逐点主根会选到大根。第 38 页原印 $m:\mathbb{H}\to\mathbb{R}$ 的值域也是笔误，应为复值（本约定下到上半平面）；期望等涂改处的收敛模式仍未决。

第 8 讲

计划：I. 回顾与目标；II. 高斯 Poincaré 不等式；III. Schur 补。

原 PDF 第 41 页

I. $M=(A+A^{\top})/\sqrt{2}$，$A=(a_{ij})_{i,j=1,\dots,N}$，$a_{ij}\overset{\text{iid}}{\sim}\mathcal{N}(0,1/N)$，且

$$m_N(z)=\frac{1}{N}\operatorname{tr}((M-zI)^{-1})=\frac{1}{N}\sum_{i=1}^{N}\frac{1}{\lambda_i-z}.$$

已证明：若存在 $m:\mathbb{H}\to\mathbb{R}$，使每个 $\epsilon,L>0$ 均有 $\sup_{|x|\le L}|m_N(x+i\epsilon)-m(x+i\epsilon)|\to 0$，且 $|\operatorname{Im} m|\le K$，则

译注： 原文 $m:\mathbb{H}\to\mathbb{R}$ 的值域写错：本节 m 为复值且取上半平面值。前讲上确界 / 期望旁的涂改未充分规定收敛模式；这里不把模糊字形补为几乎必然或一致 L^1 假设。

$$\mathbb{E}\left|\frac{1}{N}\#\{i:\lambda_i\in(a,b)\}-\int_a^b\lim_{\epsilon\downarrow 0}\frac{1}{\pi}\operatorname{Im} m(x+i\epsilon)\,dx\right|\longrightarrow 0.$$

定义。令 $m(z)$ 为满足 $m(z)(-z-m(z))=1$，即 $m(z)^2+zm(z)+1=0$，且 $|m(z)|<1$ 的唯一解。

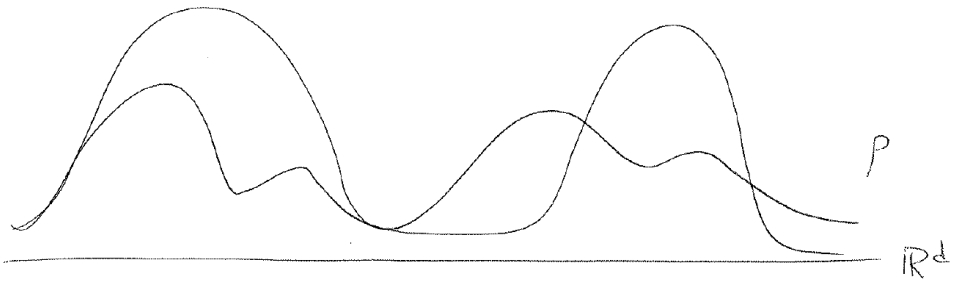
定理。对 $\epsilon>0$、$z\in\mathbb{C}$ 且 $\operatorname{Im} z=\epsilon$，

$$\text{(a)}\quad \mathbb{E}|m_N(z)-\mathbb{E}m_N(z)|\le\frac{3}{N\epsilon^2},$$
$$\text{(b)}\quad |\mathbb{E}m_N(z)-m(z)|\le\frac{7(|z|+\epsilon^{-1})}{\epsilon^5\sqrt{N}}.$$

原 PDF 第 42 页

II. 问：如何估计 $\operatorname{Var}[N^{-1}\sum_i(\lambda_i-z)^{-1}]$？这些项并不独立！

思路（Poincaré）。考虑密度 $\rho(x)>0$。原页画有几条多峰曲线示意“谷”；保存原图局部作为资产：



定义。ρ 的 Poincaré 常数为

$$C_\rho=\inf\{C>0:\operatorname{Var}_\rho[f]\le C\mathbb{E}_\rho[\|\nabla f\|^2]\ \text{对所有}f\in C^1\}.$$

解释：C_ρ 是“ρ 最大的谷”。

定理。令 $X=(X_i\sim\mathcal{N}(0,\sigma_i^2))_{i=1}^n$ 的坐标独立，则

$$\operatorname{Var}[f(X)]\le\frac{\pi^2}{8}\sum_{i=1}^n\sigma_i^2\mathbb{E}[(\partial_i f(X))^2].$$

证明。不失一般性令所有 $\sigma_i^2=1$。注意对独立同分布的 X,Y，$\operatorname{Var}[f(X)]=\frac{1}{2}\mathbb{E}[(f(X)-f(Y))^2]$。现在插值：

$$X_\theta=X\sin\theta+Y\cos\theta,\qquad \frac{d}{d\theta}X_\theta=X\cos\theta-Y\sin\theta.$$

原 PDF 第 43 页

对每个 θ，$(X_\theta, \frac{d}{d\theta}X_\theta)$ 是均值为 0、协方差为 $\begin{pmatrix} I & 0 \\ 0 & I \end{pmatrix}$ 的高斯向量。于是

$$\begin{aligned} f(X) - f(Y) &= \int_0^{\pi/2} \left\langle \nabla f(X_\theta), \frac{d}{d\theta} X_\theta \right\rangle d\theta, \\ (f(X) - f(Y))^2 &\le \frac{\pi}{2} \int_0^{\pi/2} \left\langle \nabla f(X_\theta), \frac{d}{d\theta} X_\theta \right\rangle^2 d\theta, \\ \mathrm{Var}[f(X)] &\le \frac{\pi}{4} \int_0^{\pi/2} \mathbb{E}\left[\left\langle \nabla f(X_\theta), \frac{d}{d\theta} X_\theta \right\rangle^2 \right] d\theta \\ &= \frac{\pi}{4} \int_0^{\pi/2} \mathbb{E}[\|\nabla f(X_\theta)\|^2] d\theta = \frac{\pi^2}{8} \mathbb{E}[\|\nabla f(X)\|^2]. \qquad \square \end{aligned}$$

命题。原页给出 $\mathrm{Var}[N^{-1} \operatorname{Re}\operatorname{tr}(M - zI)^{-1}]$ 与 $\mathrm{Var}[N^{-1} \operatorname{Im}\operatorname{tr}(M - zI)^{-1}]$ 均不超过 $\pi^2/(4\epsilon^4 N^2)$，从而

$$\mathbb{E}|m_N(z) - \mathbb{E}m_N(z)| \le \frac{\pi}{\sqrt{2}\,\epsilon^2 N} < \frac{3}{N\epsilon^2}.$$

证明。令 $f(M) = \mathrm{Re}(\mathrm{tr}(M - zI)^{-1})$，记 $R = (M - zI)^{-1}$；独立变量为 m_{ij}（$i > j$）及 m_{ii}。

原 PDF 第 44 页

原页写

$$\mathrm{Var}[f(M)] \le \sum_{i>j} \frac{1}{N} \mathbb{E}[(\partial_{M_{ij}} f(M))^2] + \sum_i \frac{2}{N} \mathbb{E}[(\partial_{M_{ii}} f(M))^2]. \qquad \text{(原文)}$$

译注： 此行和后续和界须带上一页证明的 $\pi^2/8$。对本节实函数 $f = \operatorname{Re}\operatorname{tr} R$，非对角导数应为 $-2\operatorname{Re}((R^2)_{ij})$，不是 $-2(R_{ij})^2$；对角为 $-\operatorname{Re}((R^2)_{ii})$。复矩阵平方范数满足 $\sum_{ij} |(R^2)_{ij}|^2 = \mathrm{tr}(R^2(R^2)^*)$，其中 $*$ 为共轭转置，不能用普通转置。随机和进入方差界时仍须保留期望；把这些修正一并计入，才得到前页的 $\pi^2/(4\epsilon^4)$ 方差尺度。原公式均保留。

为计算偏导，

$$\left.\frac{d}{dt}\right|_{t=0} \operatorname{tr}(tH + M - zI)^{-1} = -\operatorname{tr}(HR^2),$$

$$\frac{\partial f}{\partial M_{ij}} = -2R^2_{ij}, \qquad \frac{\partial f}{\partial M_{ii}} = -(R^2)_{ii}. \qquad \text{(原文)}$$

于是原页写

$$\begin{aligned} \mathrm{Var}[f(M)] &\le \frac{2}{N} \sum_{ij} |(R^2)_{ij}|^2 = \frac{2}{N} \operatorname{tr}((R^2)(R^2)^\top) \\ &= \frac{2}{N} \sum_{i=1}^N \frac{1}{|\lambda_i - z|^4} \le \frac{2}{(\operatorname{Im} z)^4}. \qquad \square \end{aligned}$$

III. 现在目标是研究 $\mathbb{E}m_N(z) = \mathbb{E}[N^{-1}\operatorname{tr}(M - zI)^{-1}] = \mathbb{E}[((M - zI)^{-1})_{11}]$。

目标 / 断言。原页写

$$\left| \mathbb{E}m_N(z) - \frac{1}{-z - \mathbb{E}m_N(z)} \right| \le \frac{7}{\epsilon^4 \sqrt{N}}.$$

原 PDF 第 45 页

写 $M - zI$ 的第一行 / 列分块，$\beta \sim \mathcal{N}(0, N^{-1} I_{N-1})$。思路：$\mathbb{E} m_N(z) = \mathbb{E}[((M - zI)^{-1})_{11}]$。

引理（Schur 补）。原页的分块记号为

$$A = \begin{pmatrix} \alpha & \beta \\ \beta^\top & \Delta \end{pmatrix}, \qquad (A^{-1})_{11} = (\alpha - \beta^\top \Delta^{-1} \beta)^{-1},$$

$$\operatorname{tr}(A^{-1}) = \operatorname{tr}(\Delta^{-1}) + (A^{-1})_{11}(1 + \beta^\top \Delta^{-2} \beta).$$

译注： 采用列向量 β 时，一致分块应写 $\left(\begin{smallmatrix} \alpha & \beta^\top \\ \beta & \Delta \end{smallmatrix}\right)$，才能与 $\beta^\top \Delta^{-1} \beta$ 相容。随后二次型中的内层还少写 $(M^{(1)} - zI)^{-1}$ 的逆号；原式保留，关键点右缘未辨部分不补。

原页进而写 $\mathbb{E}[(M_{11} - z - \beta^\top (M^{(1)} - z)\beta)^{-1}]$，括号内部的逆号未显示。

关键点。原页列出 $\mathbb{E}[M_{11}^2] = 2/N$，以及二次型与迹之差、删行列前后迹之差各为 $O(1/N)$ 的平方期望估计。第四项与第二项部分字迹被右边界截断或遮盖，保留原页关键点局部图，不猜写缺失部分。

原 PDF 第 46 页

因此原页写

$$\mathbb{E}[m_N(z)] = (-z - \mathbb{E}[m_N(z)] + \Delta_{N,\epsilon})^{-1},$$
$$\mathbb{E}[\Delta_{N,\epsilon}^2] = O(1/N).$$

原页到此结束。

译注： 上述两行按原稿保留，属于未补足的形式推导：确定量 $\mathbb{E} m_N$ 一般不能等于含随机误差的分母倒数而把期望放在外面，倒数的期望也不等于期望的倒数。复误差的 L^2 控制应为 $\mathbb{E}|\Delta_{N,\epsilon}|^2$；$\mathbb{E}\Delta^2$ 不足够，例如在 $\{1, -1, i, -i\}$ 均匀的 Δ 满足 $\mathbb{E}\Delta^2 = 0$ 而 $\mathbb{E}|\Delta|^2 = 1$。这些已写公式本身不建立所声称的自洽误差界，不猜补缺失证明。

第 9 讲

计划：I. 高斯过程定义；II. 例子；III. 特征映射与核；IV. 典范度量。

原 PDF 第 47 页

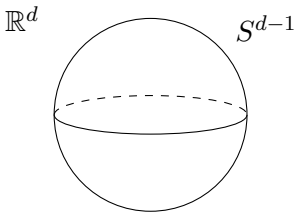
定义。设 T 是集合。T 上高斯过程是随机变量族 $(X_t)_{t \in T}$，使对所有 $t_1, \dots, t_k \in T$，向量

$$(X_{t_1}, \dots, X_{t_k})$$

都服从高斯分布，其均值由 μ_t、协方差由 $\Sigma_{s,t}$ 给出。

例 1。$T = \{1, \dots, d\}$：高斯过程就是 $\mathbb{R}^d$ 中的高斯向量。

例 2。$T = S^{d-1} \times S^{N-1}$。原页用球面图示 $S^{d-1} \subset \mathbb{R}^d$：



令 M 为 $N \times d$ 矩阵，元素独立同分布于 $\mathcal{N}(0,1)$。

原 PDF 第 48 页

令 $X_{u,v} = v^\top M u$。原页写它是 S^{d-1} 上的高斯过程，并写出均值 $\mu_{u,v} = \mathbb{E}X_{u,v} = 0$；协方差计算的主行被划除，旁注最终写出 $\mathbb{E}[X_{u,v}X_{u',v'}] = \langle u, u'\rangle\langle v, v'\rangle$。[8]

问：$\sup_{u\in S^{d-1}, v\in S^{N-1}} X_{u,v}$ 是什么？答：M 的最大奇异值！

例 3。$T = [0,1]$, $X_t = \sum_{j=0}^{N} a_j t^j$, 其中 $a_j \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$。为什么是高斯过程? 因为 $X_t = \langle \vec{a}, \overline{\Phi}_t\rangle$, $\overline{\Phi}_t = (1, t, \ldots, t^N)$。原页用图示 $[0,1]$ 经特征映射进入 $\mathbb{R}^{N+1}$：



原 PDF 第 49 页

例 4。令 $\overline{\Phi} : T \to \mathcal{H} = (V, \langle\cdot,\cdot\rangle)$, 且对每个 t 有 $\|\overline{\Phi}_t\| = \sqrt{\langle \overline{\Phi}_t, \overline{\Phi}_t\rangle} < \infty$。原页写 $X_t = \langle \vec{a}, \overline{\Phi}_t\rangle$ 是高斯过程，并在一组正交归一基中展开的级数处有划除；其均值 $\mu_t = \mathbb{E}X_t = 0$、协方差

$$\Sigma_{s,t} = \mathbb{E}[\overline{\Phi}_t^\top \vec{a}\vec{a}^\top \overline{\Phi}_s] = \langle \overline{\Phi}_t, \overline{\Phi}_s\rangle.$$

定理。每个中心高斯过程均可通过某个 $\overline{\Phi}$ 得到！问：例 1、2 的 $\overline{\Phi}$ 是什么?

译注： 无限维时 $\langle a, \overline{\Phi}_t\rangle$ 是等距高斯标量级数记号，对每个固定 t 在 L^2 收敛；a 一般不是 Hilbert 空间内的标准高斯向量，因为独立标准高斯系数的平方和几乎必然发散。此构造给有限维分布 / 典范伪度量；路径性质仍需选择合适版本，划除级数不据预期补写。

例 5。$T = [0,1]$，$\mathcal{H} = L^2([0,1], dt)$，$\langle f, g\rangle = \int_0^1 f(t)g(t)dt$。取 $\overline{\Phi}_t = \mathbf{1}_{[0,t]}$，则

$$\Sigma_{s,t} = \langle \mathbf{1}_{[0,t]}, \mathbf{1}_{[0,s]}\rangle_{L^2} = \int_0^1 \mathbf{1}_{[0,t]}(x)\mathbf{1}_{[0,s]}(x)dx = \min\{t, s\}.$$

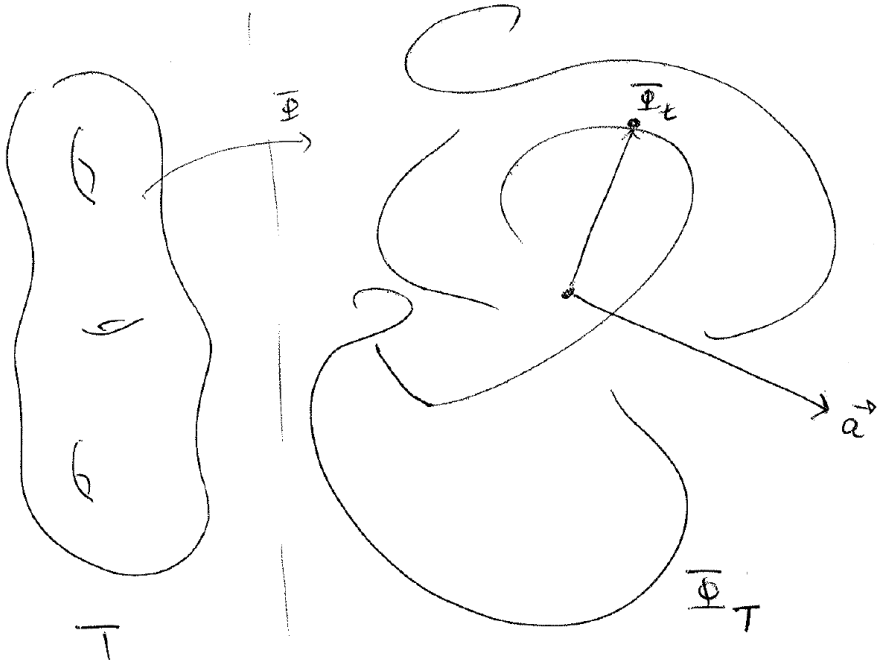
[8] 这里应以 $(u,v) \in S^{d-1} \times S^{N-1}$ 为指标，不是仅以 S^{d-1} 为指标；原文单球面说法保留。所写最终协方差与此乘积指标相符，被划除步骤不补造。

原 PDF 第 50 页

IV. 定义。设 T 为集合，$(X_t)_{t\in T}$ 为 $\mathrm{GP}(\mu,\Sigma)$。原页定义其典范度量为[9]

$$d_X^2(s,t)\equiv\mathbb{E}[|X_s-X_t|^2]=\Sigma_{s,s}+\Sigma_{t,t}-2\Sigma_{s,t}. \qquad \text{(原文)}$$

思路：典范度量赋予 T 内禀几何；高斯过程问题自然涉及这一几何。原页用特征映射与环境空间图说明：



问：如何通过 $\overline{\Phi}$ 表示 d_X？

原 PDF 第 51 页

答：$d_X^2(s,t)=\|\overline{\Phi}_s-\overline{\Phi}_t\|^2$，即环境空间中的距离！[也得到黎曼度量。]

定义。设 X 是 T 上中心高斯过程。定义

$$\mathbb{E}\left[\sup_{t\in T}X_t\right]:=\sup\left\{\mathbb{E}\left[\max_{t\in F}X_t\right]:F\subset T\text{ 有限}\right\}.$$

命题。令 $X_1,\dots,X_n$ 为中心高斯变量，$\mathrm{Var}(X_i)\le\sigma_i^2$，则原页写 $\mathbb{E}\max_{i\le n}X_i\le\sigma\sqrt{2\log n}$。[10]

证明。用 Jensen 不等式：

$$\begin{aligned}e^{\lambda\mathbb{E}[\max_{i\le n}X_i]}&\le\mathbb{E}[e^{\lambda\max_i X_i}]\le\mathbb{E}[\max_i e^{\lambda X_i}]\le\sum_i\mathbb{E}[e^{\lambda X_i}]\\&=\sum_i e^{\lambda^2\operatorname{Var}X_i/2}\le ne^{\lambda^2\sigma^2/2}.\end{aligned}$$

[9]原式保留。一般 $\mathrm{GP}(\mu,\Sigma)$ 的右侧还须加 $(\mu_s-\mu_t)^2$；只有中心化或均值恒定时可省。典范距离一般为伪度量，不同指标可能距离为 0。后页“也得到黎曼度量”另需光滑流形参数化及非退化拉回，不能对任意集合 T 成立。

[10]可明确取 $\sigma=\max_{i\le n}\sigma_i$ 为共同标准差上界。$\sigma=0$ 或 $n=1$ 时中心变量最大值的期望结论直接成立，优化参数中的除法须另行处理。

原 PDF 第 52 页

因此 $\mathbb{E}[\max_i X_i] \le (\log n)/\lambda + \lambda\sigma^2/2$。取 $\lambda = \sqrt{2\log n}/\sigma$。 □

[宽神经网络，$(f, \nabla f)$。]

命题。若 $X_1, \dots, X_n$ 独立同分布于 $\mathcal{N}(0,1)$，则 $n \to \infty$ 时 $\mathbb{E}[\max_{i\le n} X_i] = \sqrt{2\log n}\,(1+o(1))$。

证明。原页写高斯尾下界

$$\mathbb{P}(X > t) = \frac{1}{\sqrt{2\pi}} \int_t^\infty e^{-x^2/2} dx \ge \frac{e^{-3/2}}{\sqrt{2\pi}\, t} e^{-t^2/2}.$$

令 $t = \sqrt{(2-\delta)\log n}$，则 $n\mathbb{P}(X > t) \ge cn^{\delta/2}/t \to \infty$，因此[11]

$$\mathbb{P}(\max_i X_i \le t) = (1 - \mathbb{P}(X > t))^n \le e^{-n\mathbb{P}(X>t)} \to 0,$$

$$\mathbb{E}[\max_i X_i] \ge \mathbb{E}[\mathbf{1}_{\{\max_i X_i > t\}} \max_i X_i] \ge t\mathbb{P}(\max_i X_i > t)$$

$$= \sqrt{(2-\delta)\log n}\,(1 - o(1)). \qquad \square$$

原 PDF 第 53–54 页：散置的第 6 讲续页

第 53 页手写页号为带圈的 5，内容接第 6 讲路径计数；这里保持 PDF 原页序。

问：从 i 回到 i 的 $2k$ 步路径中，访问 m 个不同顶点（不含 i）的路径有多少？原页答案含一个组合数乘 d_m、渐近于 $d_m N^m$，但组合数上标有涂改；见保存的第 53 页局部图。

原页继而将 $\mathbb{E}[N^{-1}\operatorname{tr}(M^{2k})]$ 写为访问 k 个不同顶点的路径权重期望之和加 $o(1)$；求和的归一化和顶点计数未能在原页清楚辨认。对于路径 $\pi = (i, \pi(1), \dots, \pi(2k-1), i)$，原页说它有 k 条边，并恰好遍历所见每条边两次。记边为 $e_1, e_2, \dots$，按 $e_i = e_j$ 将相应位置 i, j 配对，形成配对划分。

断言。原页写 “路径数 $=$ $[k]$ 的非交叉划分数 $=$ Catalan 数”。[12]

第 54 页经 170 dpi 原页核查无正文，为空白页。

第 10 讲

原 PDF 第 55 页

回顾。$X_t = \langle a, \overline{\Phi}_t \rangle = \sum_{j\ge 0} a_j \phi_j(t)$ 是高斯过程，$a_j \sim \mathcal{N}(0,1)$；$d_X^2(s,t) = \mathbb{E}[|X_s - X_t|^2]$，且

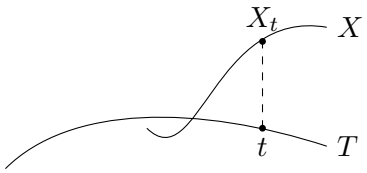
译注：无限维高斯配对仍按前讲的等距标量级数理解，对每个固定指标在 L^2 收敛；不能据此宣称 a 是空间内标准高斯向量或得到任意版本的路径上确界。

[11] 不能直接丢掉最大值非正时的负贡献。安全界为 $\mathbb{E}\max_i X_i \ge t\mathbb{P}(\max_i X_i > t) - \mathbb{E}X_1^-$，且 $\mathbb{E}X_1^- = 1/\sqrt{2\pi}$；除以 $\sqrt{\log n}$ 后该修正消失，故所需渐近仍成立。前面的高斯尾下界用于 $t \ge 1$。原推导保留。

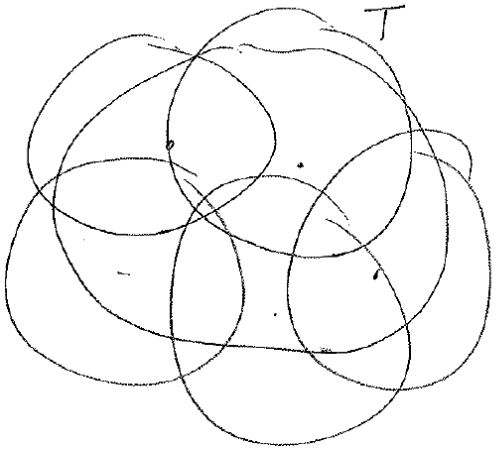
[12] 路径共有 $2k$ 个步边位置，故相应非交叉配对是 $[2k]$ 的配对；C_k 也计数 $[k]$ 的所有非交叉划分，但须另一对应。树游走的计数须按规范标号 / 无标号的有根游走理解，每条边恰走两次；原始带 N 个标签的路径另有 N 依赖因子。裁切组合数和归一化仍未辨，不补成完整证明。

$$\mathbb{E}\left[\sup_{t\in T} X_t\right] = \sup\left\{\mathbb{E}\left[\sup_{t\in F} X_t\right] : F\subset T \text{ 有限}\right\}.$$

原页另画出参数集合 T 与过程 X 的示意：



定义。(T,d) 的 ϵ-网为点集 $t_1,\dots,t_k\in T$，满足 $\bigcup_{h=1}^{k} B_\epsilon(t_h)\supseteq T$。尺度 ϵ 的覆盖数 $\mathcal{N}(T,d,\epsilon)$ 是最小 ϵ-网的大小。原页画有若干球覆盖集合 T 的示意图：



定理（Dudley 与 Sudakov）。原页写[13]

$$\mathbb{E}\left[\sup_{t\in T} X_t\right] \le 16\int_0^\infty \sqrt{\log \mathcal{N}(T,d_X,\epsilon)}\,d\epsilon, \tag{$*$}$$

$$\mathbb{E}\left[\sup_{t\in T} X_t\right] \ge \epsilon\sqrt{\log \mathcal{N}(T,d_X,\epsilon)} \quad \forall \epsilon>0. \tag{原文}$$

证明 $(*)$。固定有限 $F\subset T$，令 $D=\max_{s,t\in F} d_X(s,t)$、$\epsilon_k = D2^{-k}$。

原 PDF 第 56 页

令 Π_k 为 T 上 ϵ_k-网，$\Pi_0=\{t_0\}$，对每个 t 令 $\pi_k(t)$ 为 Π_k 中距 t 最近的点。原页以望远镜形式写

$$X_t = X_t - X_{t_0} + X_{t_0} = X_{t_0} + \sum_{k\ge 1}\big(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}\big).$$

[13]源式保留。Sudakov 下界须在中心高斯过程及典范伪度量框架下写为 $\mathbb{E}\sup X_t \ge c\epsilon\sqrt{\log\mathcal{N}(T,d_X,\epsilon)}$，其中 $c>0$ 是足够小的普适常数，不能固定为所印的 1。例如 $X_1=g, X_2=-g$，距离为 2；取 $\epsilon=1.5$ 时原右侧为 $1.5\sqrt{\log 2}\simeq 1.2488$，大于 $\mathbb{E}|g|=\sqrt{2/\pi}\simeq 0.7979$。

由此估计

$$\sup_{t\in F} X_t \le X_{t_0} + \sum_{k\ge 1} \sup_{t\in F}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)}),$$
$$\mathbb{E}\left[\sup_{t\in F} X_t\right] \le \sum_{k\ge 1} \mathbb{E}\left[\sup_{t\in F}(X_{\pi_k(t)} - X_{\pi_{k-1}(t)})\right].$$

关键点：$d_X(\pi_k(t),\pi_{k-1}(t)) \le 3\epsilon_k$。原页随后将增量的上确界以有限网点对的高斯最大值控制，末行积分的下限及覆盖数尺度有涂改和右边界截断；局部图保留于工程资产，无法可靠逐项重排。可见的中间界为 $3\epsilon_k\sqrt{2\log \mathcal{N}(T,d_X,\epsilon_k)^2} = 6\epsilon_k\sqrt{\log \mathcal{N}(T,d_X,\epsilon_k)}$，后面写以系数 12 的积分界控制。

译注：这里 D 定义为有限 F 的直径，$\Pi_0=\{t_0\}$ 只需覆盖 F，未必是整个 T 的 D-网。无限链和取期望还须先写有限链、控制余项再取极限；可得排印 08 讲义的链化证明给出了这一步，但本手写末行截断不因此认定已复原。

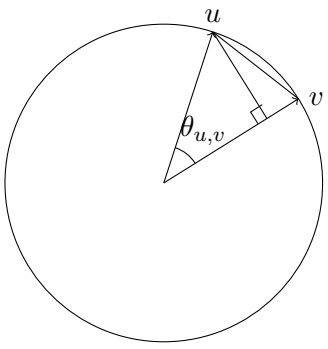
□

原 PDF 第 57 页

例。考虑 $X_u = u^\top M u$，$u\in S^{N-1}$，其中 $M=(A+A^\top)/\sqrt{2}$，$A=(a_{ij})$、$a_{ij}\sim\mathcal{N}(0,1)$。问：$X$ 是高斯过程吗？答：是。

问：$d_X^2(u,v)$ 是什么？原页展开 $\mathbb{E}[|X_u-X_v|^2]$，指标求和的末尾被扫描边界截断，继而写[14]

$$\begin{aligned} d_X^2(u,v) &= 2\sum_{ij}(u_i^2u_j^2 + v_i^2v_j^2 - 2u_iv_iu_jv_j) \\ &= 4(1-\langle u,v\rangle^2) = 4\sin^2\theta_{u,v} \ge 4\|u-v\|^2 \le 4\sqrt{2}\|u-v\|^2. \end{aligned} \qquad \text{(原文)}$$



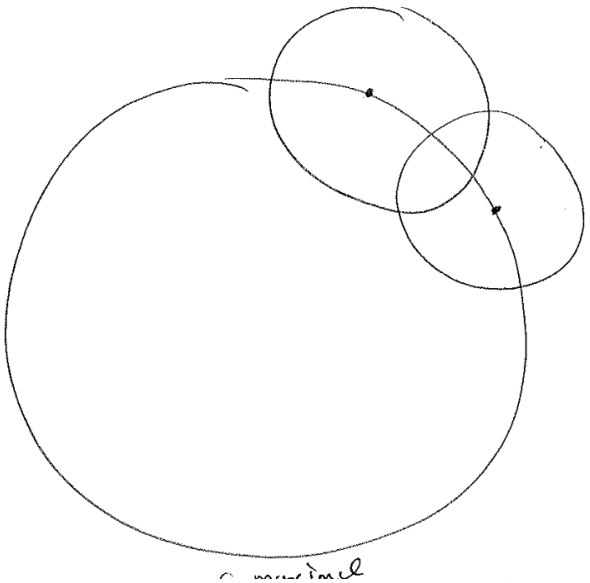
原 PDF 第 58 页

于是需要估计 $\mathcal{N}(S^{d-1},\|\cdot\|,\epsilon)$。

引理。$\mathcal{N}(S^{d-1},\|\cdot\|,\epsilon)\le(1+2/\epsilon)^d$。

证明。原页先划去一个关于覆盖球的尝试，并画出球面及相交的两个小球：

[14] 令 $r=\langle u,v\rangle$，正确比较为 $d_X^2 = 4(1-r^2) = 2(1+r)\|u-v\|^2 \le 4\|u-v\|^2$。所印 $\ge 4\|u-v\|^2$ 不成立，例如 $v=-u$ 时左侧 0、右侧 16。对跖点对应同一二次过程，不能在全球面用普通距离作这种正的下比较；下界需考虑对跖商空间或合适分离子集。原中间系数涂改及比较链保留，不默改源字形。



令 $u_1, \dots, u_n$ 是极大的 ϵ-分离集，即对 $i \neq j$ 有 $\|u_i - u_j\| > \epsilon$。则：

(1) $u_1, \dots, u_n$ 是 ϵ-网；

(2) 当 $i \neq j$，$B_{\epsilon/2}(u_i) \cap B_{\epsilon/2}(u_j) = \varnothing$；

(3) $\bigcup_i B_{\epsilon/2}(u_i) \subset B_0(1 + \epsilon/2)$。

原 PDF 第 59–60 页

故 $\mathcal{N}(S^{d-1}, \|\cdot\|, \epsilon) \leq n$，而

$$\begin{aligned} & n \operatorname{vol}(B^d_{\epsilon/2}) \leq \operatorname{vol}(B^d_{1+\epsilon/2}) \\ \iff \quad & n(\epsilon/2)^d \operatorname{vol}(B^d_1) \leq (1+\epsilon/2)^d \operatorname{vol}(B^d_1) \\ \iff \quad & n \leq (1 + 2/\epsilon)^d. \end{aligned}$$

原页于是写

$$\mathbb{E}\left[\sup_{u \in S^{d-1}} u^\top M u\right] \leq 16 \int_0^1 \sqrt{d \log(1 + 2/\epsilon)}\, d\epsilon \leq C\sqrt{d},$$

$$\mathbb{E}\left[\sup_{u \in S^{d-1}} u^\top M u\right] \geq C'\sqrt{d}.$$

第 60 页经 170 dpi 原页核查无正文，为空白页。

译注： 由正确的 $d_X \leq 2\|u - v\|$ 转移覆盖时，欧氏网半径应为 $\epsilon/2$，故 $\mathcal{N}(S^{d-1}, d_X, \epsilon) \leq (1+4/\epsilon)^d$；源末式的 $1 + 2/\epsilon$ 需要把尺度改动吸收进普适常数。Rayleigh 上确界是 $\lambda_{\max}(M)$，不是算子范数；在 $d = 1$ 时其期望为 $\mathbb{E}M_{11} = 0$，所以正的 $C'\sqrt{d}$ 下界须限定 $d \geq 2$ / 大维渐近。原式保留，缺少的下界论证不补造。