

Pre-Strings 人工智能讲义

Pre-Strings Lectures on Artificial Intelligence

Jim Halverson

美国波士顿东北大学物理系
NSF 人工智能与基础相互作用研究所
Simons 学习物理与神经计算合作项目
Physical Superintelligence, PBC
jhh@neu.edu

全文审校版

arXiv:2607.02905v1 · 2026
Model: gpt-6.1-sol（本轮全文审校 high；初译模型未核实）
审核：曹溪能
Updated: 2026-11-04

摘要

本讲义基于在上海 Pre-Strings 2026 学校三天内进行的六次讲座。第一天从场论视角出发，围绕神经网络的表达能力、统计性质和动力学，讲述神经网络的基础知识。第二天介绍一种研究场论的神经网络方法（NN-FT）：在该方法中，场论由网络架构和网络参数上的概率密度定义，并综述近期的研究成果。例子包括一个普适性定理、Liouville 理论的神经网络实现、著名的弦振幅、拓扑扇区和 Kosterlitz–Thouless 相变、Ward 恒等式与反常，以及玻色弦临界维数的一种新推导。第三天转换视角，讨论人工智能在弦论中的应用：正在改变其他技术实施方式的智能体工作流、物理信息神经网络与 Calabi–Yau 度规、弦景观和纽结理论中的强化学习与搜索，以及面向猜想生成的可解释监督学习。

目录

1 引言 **4**

2 第一天：神经网络基础 **6**

2.1 问题设定 6
2.2 神经网络的表达能力 8
2.2.1 普适逼近定理 8
2.2.2 Kolmogorov–Arnold 定理 9
2.2.3 注意力与 Transformer 9
2.3 神经网络的统计性质 12
2.3.1 神经网络与高斯过程的对应关系 13
2.3.2 非高斯过程 14
2.3.3 对称性 15
2.3.4 例子 16
2.4 神经网络的动力学 18
2.4.1 神经切线核 19
2.4.2 一个精确可解模型 20
2.4.3 特征学习 21

3 第二天：神经网络场论 **25**

3.1 NN-FT 基础 25
3.1.1 什么是场论? 25
3.1.2 按需构造自由理论 26
3.1.3 量子场论 26
3.1.4 对称性 27
3.1.5 相互作用 27
3.2 近期结果 28
3.2.1 普适性 28
3.2.2 Liouville 理论 29
3.2.3 玻色弦 30
3.2.4 拓扑缺陷与 BKT 相变 33
3.2.5 反常与 Ward 恒等式 35

4 第三天：人工智能在弦论中的应用 **39**

4.1 万事皆可用智能体 39
4.2 物理信息神经网络与 Calabi–Yau 度规 41
4.2.1 物理信息神经网络 41
4.2.2 Calabi–Yau 度规 41
4.2.3 与 Ricci 流的关系 44
4.3 强化学习与搜索 45

4.3.1 强化学习基础 45
4.3.2 探索弦真空 47
4.3.3 学习解开纽结与 Poincaré 猜想 48
4.4 猜想生成与严格性 49
4.4.1 从预测到理解 49
4.4.2 猜想生成案例 50

5 回顾与展望 **52**

A 中心极限定理 **54**

译注：原文中的约定与推导疑点 **55**

参考文献 **58**

1 引言

我在 TASI 2024 讲座 [1] 开篇时提出了一个有些挑衅的说法：计算机科学仍处于婴儿期。这一论点基于历史。从 Lovelace、Babbage 和 Turing，到 20 世纪 40 年代的密码破译、70 和 80 年代的个人计算机、90 年代的互联网、21 世纪头十年的口袋超级计算机，再到 2010 年代某种形式的人工智能 [2]，这一领域几十年来的进展不断累积，而且没有放缓的迹象。我当时猜想，未来的历史学家将以世纪而非十年来衡量计算机科学的进步，从这个视角看，我们正处在最初的起点。

现在是 2026 年 7 月，过去两年的进展使这一挑衅性的说法显得保守了。让我谈谈发生了哪些变化。

首先，语言模型学会了*推理*。2024 年 6 月的大语言模型已经令人印象深刻，但它们通过单次生成给出答案。新一代**推理模型** [3, 4] 则在长思维链上通过强化学习进行训练：模型写出推理过程，探索、回溯、自我检查，然后才作答；允许它思考的时间越长，表现就越好。这是一个动力学故事，即在推理轨迹空间中进行强化学习，它促成了在一些曾看似遥不可及的基准测试上的进展。到 2025 年 7 月，带有 Deep Think 的一个 Gemini 版本与一个实验性的 OpenAI 推理模型都在国际数学奥林匹克竞赛中取得了金牌水平的成绩 [5, 6]，在竞赛条件下解出了六道题中的五道。到 2026 年初，语言模型首次给出了一些此前文献中没有解答的 Erdős 问题 [7] 的解，证明用 Lean 形式化并经数学专家检查；到 2026 年 5 月，一个 OpenAI 推理模型 [8] 生成了一个反例，推翻了 Erdős 于 1946 年提出的单位距离猜想，九位数学家随后在一篇简短的配套论文中整理并验证了这一结果 [9]。

其次，模型学会了*行动*。将推理模型置于循环中（思考、调用工具、观察结果、再次思考 [10]）便构成一个**智能体**。如今，智能体能够编写和执行代码、搜索文献、运行计算、批评自己的输出，并在持续数小时或数天的任务中协调子智能体团队（例如 [11]）。进化式智能体系统已经有所发现：FunSearch [12] 在极值组合学中找到了新的构造，AlphaEvolve [13] 则发现了一类矩阵乘法的新方法，这是多年来的首次改进。更贴近我们的领域，智能体正日益融入理论物理的日常实践；本讲义第二天介绍的部分结果也是如此，人工智能辅助研究流程加快了其中一部分分析（与以往一样，正确性仍由人负责）。第三天我们将详细讨论智能体；届时我会论证，它们降低了本讲义中每一种机器学习用于物理的技术的成本。

本讲义面向弦论领域的博士生和博士后，源自 Strings 2026 之前在上海数学与交叉学科研究院（SIMIS）举办的 Pre-Strings 2026 学校 [14]。我有三天时间，安排如下：

- **第一天：神经网络基础**。从理论研究者的角度介绍神经网络，围绕表达能力（包括 Transformer 和推理）、统计与动力学三个支柱展开。核心内容最初为文献 [1] 准备。

- **第二天：神经网络场论**。介绍一种受机器学习理论思想启发的场论新方法。讲解基础后，后半部分讨论过去一年的结果，例如普适性、Liouville 理论、玻色弦、拓扑缺陷和 Kosterlitz–Thouless 相变，以及反常。

- **第三天：人工智能在弦论中的应用**。讨论由智能体加速的机器学习用于物理的方向，包括物理信息神经网络与 Calabi–Yau 度规、物理景观中的强化学习和搜索，以及面向猜想生成的可解释监督学习。

三天的内容相互衔接：第一天的基础构成第二天的工作语言，第三天则从理解神经网络转向用它们研究弦论问题。全文有意识地采用场论视角，既为适应听众，也因为我认为它有助于理解神经网络。

2 第一天：神经网络基础

2.1 问题设定

如果我们希望理解机器学习，至少必须理解神经网络。神经网络是一个依赖于参数 θ 的函数

$$\phi_\theta : \mathbb{R}^d \to \mathbb{R}. \tag{1}$$

标量输出已足以说明我们希望提出的基本要点；但也可以根据数据形状加入指标，以编码图像、序列等。先约定一些术语：

$$\begin{aligned}
&\text{输入：} && x \in \mathbb{R}^d, && (2)\\
&\text{输出：} && \phi_\theta(x) \in \mathbb{R}, && (3)\\
&\text{网络：} && \phi_\theta \in \mathrm{Maps}(\mathbb{R}^d, \mathbb{R}), && (4)\\
&\text{数据：} && \mathcal{D}, && (5)
\end{aligned}$$

其中数据 $\mathcal{D}$ 取决于具体问题，我们将其设想为 $\mathbb{R}^d$ 的一个子集，并可能附有标签 $y \in \mathbb{R}$。

仅凭这些结构，我们就可以提出今天讲座的核心问题：*神经网络预测什么？*固定 θ 时，答案显然是 $\phi_\theta(x)$。但从动力学和统计两方面看，这个答案过于简单。

先谈动力学。学习意味着更新参数，因此我们真正感兴趣的对象是由学习算法作用于问题而产生的轨迹：

$$\begin{aligned}
&\text{参数空间：} && \theta(t) \in \mathbb{R}^{|\theta|}, && (6)\\
&\text{输出空间：} && \phi_{\theta(t)}(x) \in \mathbb{R}, && (7)\\
&\text{函数空间：} && \phi_{\theta(t)} \in \mathrm{Maps}(\mathbb{R}^d, \mathbb{R}). && (8)
\end{aligned}$$

例如，在监督学习中，数据为

$$\mathcal{D} = \{(x_\alpha, y_\alpha) \in \mathbb{R}^d \times \mathbb{R}\}_{\alpha=1}^{|\mathcal{D}|}, \tag{9}$$

我们构造损失泛函

$$\mathcal{L}[\phi_\theta] = \sum_{\alpha=1}^{|\mathcal{D}|} \ell(\phi_\theta(x_\alpha), y_\alpha), \tag{10}$$

其中 ℓ 是单样本损失，例如 $\ell_{\mathrm{MSE}} = (\phi_\theta(x_\alpha) - y_\alpha)^2$，然后沿梯度下降：

$$\frac{d\theta_i}{dt} = -\nabla_{\theta_i} \mathcal{L}[\phi_\theta], \tag{11}$$

也可以使用梯度下降的近亲，如 SGD [15, 16]、Adam [17]，或受物理启发的能量守恒下降 [18, 19]。除非另有说明，t 始终表示训练时间。

再谈统计。计算机初始化网络时，参数是抽样得到的：

$$\theta \sim P(\theta), \tag{12}$$

不同的参数样本给出不同函数。任何一个样本都不比其他样本更受偏好，因此单个随机初始化网络的逐点预测 $\phi_\theta(x)$ 不可能是基本对象。基本对象是系综：平均预测、二阶矩

$$\mathbb{E}[\phi_\theta(x)] = \int d\theta\, P(\theta)\phi_\theta(x), \tag{13}$$

$$\mathbb{E}[\phi_\theta(x)\phi_\theta(y)] = \int d\theta\, P(\theta)\phi_\theta(x)\phi_\theta(y), \tag{14}$$

以及更高阶矩，其中期望是对初始化取的。我们是物理学家，因此写作 $\mathbb{E}[\cdot] = \langle\cdot\rangle$，并认出熟悉的对象：

$$G^{(1)}(x) = \langle\phi_\theta(x)\rangle, \tag{15}$$

$$G^{(2)}(x,y) = \langle\phi_\theta(x)\phi_\theta(y)\rangle. \tag{16}$$

网络系综的平均预测和二阶矩就是一点和两点关联函数。我们已经看到，场论语言出现在了机器学习中。

结合动力学和统计：每次初始化都产生一条轨迹，因此我们有一个轨迹系综，可用含时密度

$$\theta(t) \sim P_t(\theta) \tag{17}$$

和含时关联函数

$$G_t^{(1)}(x) = \langle\phi_\theta(x)\rangle_t, \tag{18}$$

$$G_t^{(2)}(x,y) = \langle\phi_\theta(x)\phi_\theta(y)\rangle_t \tag{19}$$

描述，其中关联函数在随时间演化的参数密度下求取。如果训练发挥作用，我们尤其关心晚期行为，例如

$$G_\infty^{(1)}(x) = t \to \infty \text{ 时无穷多个神经网络的平均预测},$$

值得注意的是，我们将看到，在特定的监督学习情形中，这个量可以精确求解。

还需要另一个支柱。考虑架构

$$\phi_\theta(x) = \theta \cdot x. \tag{20}$$

这是一个线性模型，对它进行学习就是线性回归；它无法解决任何有意义的非线性问题。该模型的表达能力不够。我们需要足够丰富的架构来逼近基本上任意的对象，这尤其要求非线性。

因此我们通过三个**支柱**研究神经网络，每个支柱各有一个问题：

- 表达能力：神经网络有多强大？
- 统计：神经网络系综是什么？
- 动力学：它如何演化？

物理学家的视角意味着使用物理学家的工具（研究系综的场论、研究损失的景观动力学、不同背景下的对称性），也意味着物理学家对严格性的标准：重视机制和玩具模型而非定理，同时控制直觉。这适合实验远远领先于理论的领域，其中首先需要的是对经验现象的 $O(1)$ 量级的理解。

从现在起，我们通常省略下标，用 $\phi(x)$ 表示 $\phi_\theta(x)$；对参数的依赖始终存在。

2.2 神经网络的表达能力

神经网络是由许多小函数复合而成的大函数，复合的方式由网络架构决定。复合带来灵活性，因此我们问：*神经网络有多强大？*这归根结底是关于函数逼近的数学问题，经典的回答是逼近定理。

2.2.1 普适逼近定理

这些结果中最著名的或许是普适逼近定理（UAT）：只需一个隐藏层，就能以任意给定精度逼近紧集上的任意连续函数。Cybenko 的原始版本如下：

定理 2.1 (Cybenko [20])**.** *设 $f : \mathbb{R}^d \to \mathbb{R}$ 是紧集 $K \subset \mathbb{R}^d$ 上的连续函数。那么对任意 $\epsilon > 0$，存在一个具有单个隐藏层的神经网络，形式为*

$$\phi(x) = \sum_{i=1}^{N} w_i^{(1)} \sigma\left(\sum_{j=1}^{d} w_{ij}^{(0)} x_j + b_i^{(0)} \right) + b^{(1)}, \tag{21}$$

其中 $\theta = \{w_{ij}^{(0)}, w_i^{(1)}, b_i^{(0)}, b^{(1)}\}$，$\sigma : \mathbb{R} \to \mathbb{R}$ 是非多项式的非线性激活函数，使得

$$\sup_{x \in K} |f(x) - \phi(x)| < \epsilon. \tag{22}$$

架构 (21) 有许多名称：感知机、全连接网络、**前馈网络**。整数 N 称为**宽度**。将仿射映射和非线性运算堆叠 L 次，便加入了一个**深度**维度，得到多层感知机（MLP）或深度前馈网络。

尽管 UAT 很有力，它有两个值得记住的盲点：它没有说明给定精度需要多少神经元，也没有说明如何找到合适的参数。参数空间中存在一个优秀的逼近器 θ^*，并不意味着梯度下降一定能到达那里。后者是动力学问题，我们还会再讨论。

一个显然的问题是：*为什么 UAT 成立？*Cybenko 研究的是 sigmoid 函数

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \tag{23}$$

这一选择便于用图展示其机制。每个单元贡献

$$\sigma\left(w_i^{(0)} \cdot x + b_i^{(0)} \right), \tag{24}$$

当 $w^{(0)} \to \infty$ 时，它趋于一个平移的阶跃函数。阶跃函数之差形成局域凸起，输出权重 $w^{(1)}$ 缩放这些凸起，再用凸起拼出所需的函数；参见图 1。Cybenko 的定理 [20] 只是起点；此后出现了大量推广，包括多个隐藏层 [21]、其他激活函数和其他定义域。

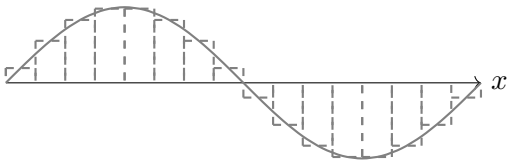


图 1: 普适逼近定理背后的机制：用一系列凸起拼出 $\sin(x)$ 或其他函数，而这些凸起由（近似）阶跃函数之差构成。

2.2.2 Kolmogorov–Arnold 定理

UAT 表明，复杂函数可以由简单构件组装而成。人们自然会问还有哪些定理具有类似特点，以及它们是否也能启发网络架构。

一个优美的例子来自 Kolmogorov [22] 和 Arnold [23]：任意多元连续函数都可以仅用一元函数和加法写出——即精确表示，而非仅仅逼近：

定理 2.2 (Kolmogorov–Arnold 表示定理)**.** *设 $f : [0,1]^n \to \mathbb{R}$ 为任意多元连续函数。那么它可以表示为*

$$f(x_1, \ldots, x_n) = \sum_{q=0}^{2n} \Phi_q \left(\sum_{p=1}^{n} \phi_{q,p}(x_p) \right), \tag{25}$$

其中 Φ_q 和 $\phi_{q,p}$ 是连续的一元函数。

乍看之下，这似乎好得难以置信：若一元函数加法已足够，$f(x,y) = xy$ 又怎样？这个特例并不神秘，

$$f(x,y) = xy = e^{\log x + \log y}, \tag{26}$$

但一般的结论极不平凡。或者，如果希望在整个单位正方形上讨论，可以写成

$$f(x,y) = xy = \frac{1}{4}(x+y)^2 - \frac{1}{4}(x-y)^2. \tag{27}$$

仔细看式 (25) 的结构：它是对函数之和再取函数的求和，这让人联想到神经网络。但有一个转折：内层函数 $\phi_{q,p}$ 同时带有指标 p 和 q，所以自然位于连接输入 x_p 与中间量 $x_q^{(1)} := \sum_p \phi_{q,p}(x_p)$ 的边上，而不同的边携带独立的函数。如果这是一个网络，那么它的激活函数位于边上而非节点上，并且自身是可学习的。

这一观察引出了 Kolmogorov–Arnold 网络（KAN） [24]：这是一种具有可学习边激活函数的架构，可以堆叠成深层网络，就如单层 UAT 结构可以堆叠成 MLP 一样。图 2 给出了比较。KAN 在实践中的一个显著特点是，学到的一元激活函数可以可视化，且通常可以转换为符号形式，从而得到能够映射到闭式表达式的可解释模型。第三天讨论猜想生成时，我们将利用这一特点。

2.2.3 注意力与 Transformer

UAT 与 Kolmogorov–Arnold 定理都从固定输入向量 $x \in \mathbb{R}^d$ 出发，探讨在其上能构造什么。然而，引言中推理模型和智能体使用的语言并非以固定向量的形式出现，而是以长度可变的 token 序列出现。因此我们问：*什么架构能够读取序列？*

主要的答案是**注意力** [25]，其直觉来自语言。**Token** 是模型读取的基本单位：**分词**将原始文本拆成这些单位（通常采用字节对编码等基于频率的方案选择子词片段，因此常见单词保持完整，罕见单词则被拆开），每个单位映射为整数编号，再映射为一个可学习的嵌入向量。假设 token 就是英语句子中的单词（真实系统使用子词片段，但用单词足以说明问题）。每个单词带有一个*无上下文*嵌入：可以把它想象成《牛津英语词典》中的词条，一个列出该词所有可能含义的固定向量。无论你站在河边还是金库里，`bank` 的词条都一样。然而，人们读的不是词典，而

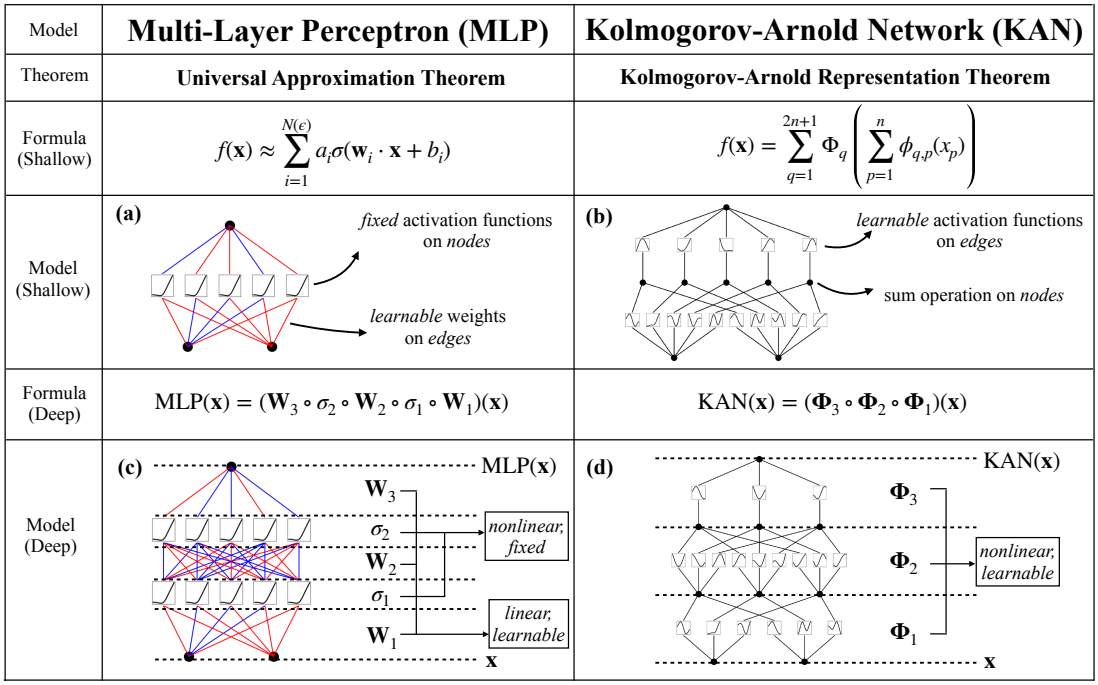


图 2: MLP 与 KAN 的比较：其函数形式、启发各自架构的数学定理，以及各自如何堆叠成层。
译注：图内文字对照。原图保留，数学符号、公式和连线不作改动。

Model；Theorem	模型；定理
Multi-Layer Perceptron (MLP)	多层感知机（MLP）
Kolmogorov-Arnold Network (KAN)	Kolmogorov–Arnold 网络（KAN）
Universal Approximation Theorem	普适逼近定理
Kolmogorov-Arnold Representation Theorem	Kolmogorov–Arnold 表示定理
Formula (Shallow)；Model (Shallow)	浅层公式；浅层模型
Formula (Deep)；Model (Deep)	深层公式；深层模型
fixed activation functions on nodes	节点上的固定激活函数
learnable weights on edges	边上的可学习权重
learnable activation functions on edges	边上的可学习激活函数
sum operation on nodes	节点上的求和运算
nonlinear, fixed；linear, learnable	非线性、固定；线性、可学习
nonlinear, learnable	非线性、可学习

是句子，并通过查看相邻词——例如 `river` 或 `deposit`——确定每个词的含义。**自注意力**正是这一操作：它让每个 token 从其余 token 收集信息，从而将其无上下文词条变成依赖上下文的表示。

具体地，把每个 token 向量记为 $x \in \mathbb{R}^d$，其中 d 是嵌入维数，将 n 个向量堆成 $X \in \mathbb{R}^{n\times d}$ 的各行。每个 token 发出**查询** $q = xW_Q$（我需要什么上下文?），给出**键** $k = xW_K$（我提供什么上下文?），并携带**值** $v = xW_V$（它传递的内容）；其中 $W_Q, W_K \in \mathbb{R}^{d\times d_k}$ 与 $W_V \in \mathbb{R}^{d\times d_v}$ 是可学习的。由于查询、键和值都由同一个 X 构造，这个具体例子是*自注意力*。经过 softmax 归一化的查询与键之间的相容性决定谁听取谁的信息：

$$\begin{aligned} \mathrm{Attn}(X) &= \underbrace{\mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)}_{A} V, \\ Q = XW_Q, &\qquad K = XW_K, \qquad V = XW_V. \end{aligned} \tag{28}$$

这里

$$\mathrm{softmax}(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}} \tag{29}$$

将每一行原始的查询–键分数转换为正的归一化分布（以概率方式选择读取什么，而非确定性地挑选），因此注意力矩阵 $A \in \mathbb{R}^{n\times n}$ 的每一行之和都是一。A 的第 i 行是 token i 所关注的各 token 上的一个分布：`bank` 将权重放在 `river` 上。

并行运行 N 个这样的映射便得到**多头注意力**；这里的头数就是第 2.3 节 NNGP 列表中的 N。查询和键要做点积，因此维数必然相同，即 $d_q = d_k$；实践中还取 $d_k = d_v = d/N$，称为**头维数**，使 N 个头拼接后回到完整宽度 d。将多头注意力与逐 token 的 MLP、残差连接和归一化交错，就得到 **Transformer** 块 [25]；堆叠 L 个块便得到本讲义中每个语言模型、推理模型和智能体所依赖的架构。自注意力按构造具有置换等变性；词序通过在输入中加入**位置编码**重新注入：将依赖位置的向量（token 索引的固定正弦函数，或每个位置的可学习嵌入）加到 token 嵌入上，使不同位置处原本相同的 token 可以区分。

当 Q, K, V 都来自同一序列时，称为**自注意力**；当查询来自一个序列，而键和值来自另一个序列时（例如解码器关注编码器输出），称为**交叉注意力**。最初的 Transformer 是用于翻译的编码器–解码器 [25]；如今大多数语言模型是**仅解码器**模型 [26]，即单个因果堆栈，根据之前的 token 预测下一个 token。**掩码**保证了“因果性”：在 softmax 之前，指向未来位置的注意力分数被设为 $-\infty$（A 的严格上三角部分），使 token i 只能关注编号 $\le i$ 的 token，预测下一个 token 时不会偷看未来。模型通过自监督的下一 token 预测训练，在大型语料库上最小化给定前文时每个 token 的交叉熵；之后再通过后训练（指令微调及第三天介绍的 GRPO 等强化学习）塑造其行为。

有了这些重要背景，我们应回到表达能力的问题。Transformer 在原则上是否隐藏着某种局限？和感知机一样，答案是否定的：

定理 2.3 (Yun 等 [27])**.** *加入位置编码后，Transformer 是紧致定义域上连续序列到序列函数的普适逼近器。*

这是针对序列数据的 UAT 类似物。

但表达能力的故事还有第二章。固定深度的 Transformer 在每次前向传播中执行固定数量的串行计算步骤，这可以被证明会限制单次传播所能表达的内容：内在具有顺序性的问题无法处理。让模型输出中间 token 并将其重新读入（即**思维链** [28]），就相当于按需提供串行步骤：它的表达能力现在会随推理长度增长 [29, 30]。引言中经过后训练、在回答前进行思考的推理模型 [3, 4]，正是利用了这一点。

推理即表达能力。用 token 思考，通过消耗测试时计算来换取表达能力。

我们还会再次遇到这一架构：冗余变换 $W_Q \to RW_Q$、$W_K \to RW_K$ 保持 $W_Q^T W_K$ 不变[1]，它在第二天的反常形式体系中重新出现为规范对称性（第 3.2.5 节）；第三天，读取辫子词的 Transformer 将用于对纽结分类（第 4.3 节）。

2.3 神经网络的统计性质

现在来理解初始化时的神经网络，尽管这里的问题对任意固定时间 t 及其对应的 $P_t(\theta)$ 都成立。

只启动一次笔记本电脑还不够：一次初始化只对应一次抽样 $\theta \sim P(\theta)$，因而只给出一个随机函数。研究对象是*系综：什么刻画了神经网络系综的统计性质？*矩，或称 n 点函数，

$$G^{(n)}(x_1, \ldots, x_n) = \langle \phi(x_1) \ldots \phi(x_n) \rangle, \tag{30}$$

将这些信息打包，它们都可由配分函数得到：

$$Z[J] = \left\langle e^{\int d^d x \, J(x)\phi(x)} \right\rangle, \tag{31}$$

$$G^{(n)}(x_1, \ldots, x_n) = \left(\frac{\delta}{\delta J(x_1)} \cdots \frac{\delta}{\delta J(x_n)} Z[J] \right) \Bigg|_{J=0}, \tag{32}$$

其中 $J(x)$ 是源。我有意不具体指定括号 $\langle \cdot \rangle$ 的含义。使用问题设定中的期望，

$$Z[J] = \int d\theta \, P(\theta) e^{\int d^d x \, J(x)\phi(x)}, \tag{33}$$

这是对网络参数密度的积分；请记住 $\phi(x)$ 依赖于 θ。然而，物理学家习惯于同类对象的另一种表示：

$$Z[J] = \int \mathcal{D}\phi \, e^{-S[\phi]} e^{\int J(x)\phi(x)}, \tag{34}$$

即 Feynman 路径积分，其中函数上的密度由作用量 $S[\phi]$ 给出。

指定一个神经网络意味着指定一对数据 $(\phi, P(\theta))$，因此*参数空间配分函数* (33) 是自然的研究对象，关联函数总可由它计算。给定这些数据，一个自然问题是：*与 $(\phi, P(\theta))$ 对应的作用量 $S[\phi]$ 是什么？*只要这个问题有答案，同一理论就有两种表述，参数空间和函数空间描述或许值得称为一种*对偶性*。

[1] 译注：这里的变换及不变性说法按原文保留，但依前述 $Q = XW_Q$、$K = XW_K$ 的行向量约定，注意力分数涉及 $W_Q W_K^T$；一般左乘 R 并不保持该量。即使考虑 $W_Q^T W_K$，也须对 R 的维数和正交性作适当限制。此处记号及约定需进一步核查。

2.3.1 神经网络与高斯过程的对应关系

既然已经提出 $S[\phi]$ 的问题，我们转向 Neal [31] 在 20 世纪 90 年代得到的一个经典结果。

考虑宽度为 N 的单层全连接网络；为简化记号，关闭偏置：

$$\phi(x) = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} w_i^{(1)} \sigma\left(\sum_{j=1}^{d} w_{ij}^{(0)} x_j \right), \tag{35}$$

其参数 $\theta = \{w_{ij}^{(0)}, w_i^{(1)}\}$ 独立同分布（i.i.d.）抽取：

$$w_{ij}^{(0)} \sim P(w^{(0)}), \qquad w_i^{(1)} \sim P(w^{(1)}). \tag{36}$$

观察式 (35) 可以发现：网络是 N 个独立同分布函数的和。这是函数空间中的中心极限定理（标量版本见附录 A），它给出神经网络与高斯过程（NNGP）的对应关系：在 $N \to \infty$ 极限下，ϕ 从高斯过程（GP）中抽取，

$$\lim_{N\to\infty} \phi(x) \sim \mathcal{N}\left(\mu(x), K(x,y)\right), \tag{37}$$

其中 $\mu(x)$ 是均值，$K(x,y)$ 是协方差（核）。根据中心极限定理，$\exp(-S[\phi])$ 变为高斯形式，即 $S[\phi]$ 是网络的二次型。这应该让物理学家提高警觉：无限宽网络是从函数上的高斯密度中抽样得到的，也就是说，它是一个广义自由场论。

在讨论这一结果有多普遍之前，先来计算。取 $P(w^{(1)})$ 为零均值且具有有限方差：

$$\langle w^{(1)} \rangle = 0, \qquad \langle w^{(1)} w^{(1)} \rangle = \mu_2, \tag{38}$$

于是单点函数消失：$G^{(1)}(x) = 0$。依照 Williams [32]，直接在参数空间计算两点函数（采用 Einstein 求和约定）：

$$\begin{aligned} G^{(2)}(x,y) &= \frac{1}{N} \langle w_i^{(1)} \sigma(w_{ij}^{(0)} x_j) w_k^{(1)} \sigma(w_{kl}^{(0)} y_l) \rangle & (39)\\ &= \frac{1}{N} \langle w_i^{(1)} w_k^{(1)} \rangle \langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{kl}^{(0)} y_l) \rangle & (40)\\ &= \frac{\mu_2}{N} \langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l) \rangle, & (41) \end{aligned}$$

其中用到了独立同分布给出的 $\langle w_i^{(1)} w_k^{(1)} \rangle = \mu_2 \delta_{ik}$。剩下的 i 求和包含 N 个相同副本，故

$$G^{(2)}(x,y) = \mu_2 \langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l) \rangle, \tag{42}$$

现在不对 i 求和。这个结果对 N 是精确的，余下仅有尖括号，即对 $w^{(0)}$ 的有限维积分。如果可以就解析计算；否则可对 M 个样本 $w^{(0)} \sim P(w^{(0)})$ 使用 Monte Carlo 方法：

$$G^{(2)}(x,y) \simeq \frac{\mu_2}{M} \sum_{\text{样本}}^{M} \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l), \tag{43}$$

标准的神经网络参数密度通常被选为容易采样的形式。（对较难采样的密度，可以使用马尔可夫链 Monte Carlo，如同格点场论中所做的那样。）

这就确定了 NNGP：

$$\lim_{N\to\infty} \phi(x) \sim \mathcal{N}\left(0, G^{(2)}(x,y)\right), \tag{44}$$

其作用量为

$$S[\phi] = \frac{1}{2}\int d^d x\, d^d y\, \phi(x) G^{(2)}(x,y)^{-1} \phi(y), \tag{45}$$

其中逆由下式定义：

$$\int d^d y\, G^{(2)}(x,y)^{-1} G^{(2)}(y,z) = \delta^{(d)}(x-z). \tag{46}$$

因此，对于任意均值为零的 NNGP，只需在参数空间计算 $G^{(2)}$ 并求逆，就得到了作用量。

因此，某些大型神经网络是从广义自由场论中抽取的。你应该会问：*NNGP 对应关系有多普遍？*Neal 对单层前馈网络证明了它，随后这个结果多年鲜有人问津；我猜测，原因是 AI 寒冬以及当时领域重心在非神经网络方法上。2010 年代 AlexNet [33] 问世后神经网络兴起，人们逐一针对不同架构提出问题：架构 X 是否有一个结构超参数 N，使其 $N \to \infty$ 的极限是高斯过程？看下列列表之前，不妨先问自己：*Neal 的结果只不过是将中心极限定理应用于 N 个独立同分布函数的和。这种情况在神经网络中常见吗？*

答案是肯定的，因此 NNGP 极限随处可见：

- **深度全连接网络**，$N =$ 宽度；
- **卷积神经网络**，$N =$ 通道数；
- **注意力网络**，$N =$ 注意力头数。

还有更多；统一处理见文献 [34] 及其中的参考文献。

2.3.2 非高斯过程

如果高斯性来自中心极限定理，那么相互作用（用场论语言说，就是非高斯性）就来自对中心极限定理假设的破坏。由附录 A 可知，有两个途径：有限 N 修正和统计独立性的破缺。文献 [35] 系统研究了独立性的破缺，包括从关联函数提取神经网络作用量。

我们来展示连通四点函数对 N 的依赖。Williams 的技巧适用于任意关联函数；为避免繁琐的指标运算，我们将架构写为

$$\phi(x) = \frac{1}{\sqrt{N}} \sum_i w_i \varphi_i(x), \tag{47}$$

其中 w_i 的分布与上面的输出权重相同，$\varphi_i(x)$ 是具有任意内部架构的独立同分布神经元。那么

$$\begin{aligned} G^{(4)} &= \langle \phi(x)\phi(y)\phi(z)\phi(w)\rangle && (48)\\ &= \frac{1}{N^2}\sum_{i,j,k,l} \langle w_i w_j w_k w_l\rangle \langle \varphi_i(x)\varphi_j(y)\varphi_k(z)\varphi_l(w)\rangle && (49)\\ &= \frac{1}{N^2}\sum_i \langle w_i^4\rangle \langle \varphi_i(x)\varphi_i(y)\varphi_i(z)\varphi_i(w)\rangle && (50)\\ &\quad + \frac{1}{N^2}\sum_{i\neq j} \langle w_i^2\rangle\langle w_j^2\rangle \langle \varphi_i(x)\varphi_i(y)\varphi_j(z)\varphi_j(w) + \text{置换}\rangle. && (51) \end{aligned}$$

留心指标：它们发挥着重要作用。连通四点函数

$$G_c^{(4)}(x,y,z,w) = G^{(4)}(x,y,z,w) - \big(G^{(2)}(x,y)G^{(2)}(z,w) + \text{置换}\big) \tag{52}$$

计算得到

$$G_c^{(4)}(x,y,z,w) = \frac{1}{N}\bigg(\mu_4\langle\varphi_i(x)\varphi_i(y)\varphi_i(z)\varphi_i(w)\rangle \tag{53}$$

$$- \mu_2^2\big(\langle\varphi_i(x)\varphi_i(y)\rangle\langle\varphi_i(z)\varphi_i(w)\rangle + \text{置换}\big)\bigg), \tag{54}$$

其中不对 i 作 Einstein 求和。连通四点函数是 $O(1/N)$：有限宽度意味着相互作用，强度由 $1/N$ 控制。在下文例子中，$G_c^{(4)}$ 可以用闭式计算。

更一般地，连通关联函数具有中心极限定理的 N 标度：

$$G_c^{(2n)} \propto \frac{1}{N^{n-1}}, \qquad n \geq 2, \tag{55}$$

这解释了为什么在 $N \to \infty$ 极限下，高阶连通关联函数消失，仅剩两点函数和高斯性。

2.3.3 对称性

我们已初步掌握统计性质。下一个问题是：*系综是否具有结构*？也就是说，是否有单个网络并不了解的系综性质？这一问题的广义版本是第二天的主题；此处我们着重讨论对称性。

为了容纳作用于输入与输出的对称性，考虑网络

$$\phi : \mathbb{R}^d \to \mathbb{R}^D, \tag{56}$$

其输出为 D 维，有时省略指标。

单个网络层面的一个经典概念是等变性 [36]。对于群 G，如果网络满足

$$\rho_D(g)\phi(x) = \phi(\rho_d(g)x), \qquad \forall g \in G, \tag{57}$$

则它是 G-**等变的**，其中 ρ_d, ρ_D 是 G 在输入与输出空间上的矩阵表示；当 $\rho_D = \mathbf{1}$ 时网络是**不变的**。将合适的等变性纳入架构，可以显著提高学习速度与样本效率 [37]，甚至改善标度律 [38, 39, 40]；格点场论研究者会认出 $SU(N)$ 等变流 [41] 是一个重要的物理例子。

不过这是统计讲座，因此我们关注*系综*的对称性，即保持统计系综不变的变换。在场论中，这些是**全局对称性**。令网络按下式变换：

$$\phi \mapsto \phi_g, \qquad g \in G. \tag{58}$$

如果配分函数不变，则系综具有全局对称群 G：

$$Z_g[J] = Z[J], \qquad \forall g \in G, \tag{59}$$

即

$$\left\langle e^{\int d^dx\, J(x)\phi_g(x)} \right\rangle = \left\langle e^{\int d^dx\, J(x)\phi(x)} \right\rangle, \qquad \forall g \in G, \tag{60}$$

必要时 ϕ 和 J 带指标。在左侧重新定义网络后，该陈述就成为 $\langle\cdot\rangle$ 本身的不变性。在路径积分中，这就是熟悉的 $S[\phi]$ 和 $\mathcal{D}\phi$ 的不变性。在参数空间中，机制 [42] 是将 g 吸收到重参数化 $\theta \mapsto \theta_g$ 中；当下式成立时对称性成立：

$$\int d\theta_g\, P(\theta_g) e^{\int d^d x\, J(x)\phi_\theta(x)} = \int d\theta\, P(\theta) e^{\int d^d x\, J(x)\phi_\theta(x)}, \tag{61}$$

即在吸收后的作用下参数密度和测度不变。请记住这种吸收机制：第二天它将推动我们对 Ward 恒等式与反常的分析。

对输入或输出作变换，分别给出时空对称性和内部对称性的类似物；如果希望学习到具有对称性的表示，也可以考虑中间层的变换。等变性自然适用于这里，它将输入变换转化为输出变换，后者诱导的作用还必须保持配分函数不变。

例子。 对任意具有形式

$$\phi(x) = \sum_i w_i \varphi_i(x), \qquad w_i \sim P(w) \text{ 为偶函数}, \tag{62}$$

的架构，其中神经元 φ 可以任意（无论深层还是浅层），$\mathbb{Z}_2$ 作用 $\phi \mapsto -\phi$ 可被 $w_g = -w$ 吸收，而 $P(w)$ 的偶性使 $dw\, P(w)$ 不变。只要定义域不变，这就是一个全局对称性，所有奇数阶关联函数都消失。

2.3.4 例子

我们已经收集了三种统计现象：高斯极限、违反中心极限定理而产生的非高斯性，以及对称性。让我们通过几个具体架构来看这些现象。对于使用 ReLU 的网络等标准机器学习情形，参见文献 [43] 及其中的参考文献。

Gauss-net。 架构与参数密度为：

$$\phi(x) = \frac{w_i^{(1)} \exp(w_{ij}^{(0)} x_j + b_i^{(0)})}{\sqrt{\exp\left[2\left(\sigma_{b_0}^2 + \frac{\sigma_{w_0}^2}{d} x^2\right)\right]}}, \tag{63}$$

其中各参数独立同分布抽取：

$$w^{(0)} \sim \mathcal{N}\left(0, \frac{\sigma_{W_0}^2}{d}\right), \quad w^{(1)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_1}^2}{2N}\right), \quad b^{(0)} \sim \mathcal{N}(0, \sigma_{b_0}^2). \tag{64}$$

两点函数是

$$G^{(2)}(x_1, x_2) = \frac{\sigma_{w_1}^2}{2} e^{-\frac{1}{2d}\sigma_{w_0}^2 (x_1 - x_2)^2}, \tag{65}$$

呈现出关联长度

$$\xi = \sqrt{\frac{d}{\sigma_{w_0}^2}}. \tag{66}$$

连通四点函数为

$$G_c^{(4)} = \frac{\sigma_{w_1}^4}{4N}\Bigg[3e^{4\sigma_{b_0}^2} e^{-\frac{\sigma_{w_0}^2}{2d}\sum_i x_i^2 - 2(x_1x_2 + 6\text{ 个置换})} - \left(e^{-\frac{1}{2d}\sigma_{w_0}^2\left((x_1-x_4)^2+(x_2-x_3)^2\right)} + 2\text{ 个置换}\right)\Bigg]. \tag{67}$$

注意其中的不对称性：两点函数具有平移不变性，四点函数却没有。

欧氏不变网络。 假设我们希望在输入层构造完整欧氏群（$SO(d)$ 旋转和平移）的不变性。考虑

$$\ell_i(x) = F(\mathbf{w}_i^{(0)}) \cos\left(\sum_j w_{ij}^{(0)} x_j + b_i^{(0)}\right), \quad i \in \{1, \ldots, N\}, \tag{68}$$

这里显式写出求和，因为不对 i 求和，并且

$$w_{ij}^{(0)} \sim P(w_{ij}^{(0)}), \qquad b_i^{(0)} \sim \mathrm{Unif}[-\pi, \pi]. \tag{69}$$

旋转 $x_i \to R_{ij}x_j$（$R \in SO(d)$）可吸收到 $w_{ij}^{(0)}$ 的重定义中；只要 $F(\mathbf{w}_i^{(0)})$ 和 $P(w_{ij}^{(0)})$ 具有旋转不变性，配分函数便保持不变。平移 $x_j \to x_j + \epsilon_j$ 产生 $w_{ij}^{(0)}\epsilon_j$，可将其吸收到均匀相位 $b_i^{(0)}$ 中。两点值得强调：

- **更大的欧氏网络**。任何建立在 ℓ 之上且不重复使用其参数的网络，都继承欧氏不变性。
- **谱的塑形**。在 $G^{(2)}(p)$ 中，函数 F 在动量处取值，可选择它来任意塑造功率谱（动量空间传播子）。

一般关联函数见文献 [44]；请记住谱的塑形，因为第二天将大量依赖它。通过与输出权重缩并，可以得到标量神经网络：

$$\phi(x) = \sum w_i^{(1)} \ell_i(x), \qquad w_i^{(1)} \sim P(w^{(1)}). \tag{70}$$

Cos-net。 将式 (70) 具体化为 $F = 1$：

$$\phi(x) = w_i^{(1)} \cos\left(w_{ij}^{(0)} x_j + b_i^{(0)}\right), \tag{71}$$

其密度为

$$w^{(1)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_1}^2}{N}\right), \quad w^{(0)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_0}^2}{d}\right), \quad b^{(0)} \sim \mathrm{Unif}[-\pi, \pi]. \tag{72}$$

两点函数与 Gauss-net 的相同：

$$G^{(2)}(x, y) = \frac{\sigma_{w_1}^2}{2} e^{-\frac{1}{2d}\sigma_{w_0}^2 (x-y)^2}, \tag{73}$$

而连通四点函数为

$$G^{(4)}\big|_c = \frac{\sigma_{w_1}^4}{8N}\Bigg[3\left(e^{-\frac{1}{2d}\sigma_{w_0}^2 (x_1+x_2-x_3-x_4)^2} + 2\text{ 个置换}\right) - \left(2e^{-\frac{1}{2d}\sigma_{w_0}^2\left((x_1-x_4)^2+(x_2-x_3)^2\right)} + 2\text{ 个置换}\right)\Bigg], \tag{74}$$

具有完整的欧氏不变性。比较这两种架构：

- **对称性**。按照构造，Cos-net 对每个 N 都具有欧氏不变性；Gauss-net 只有在 $N \to \infty$ 时才有，此时理论完全由 $G^{(2)}$ 确定。
- **大 N 对偶**。当 $N \to \infty$ 时，两种理论收敛到同一个高斯过程。

Scalar-net。 最后一个例子用来再现自由标量场。将式 (70) 具体化为

$$\phi(x) = \sqrt{\frac{2\,\mathrm{vol}(B_\Lambda^d)}{(2\pi)^d \sigma_{w_1}^2}} \frac{1}{\sqrt{(\mathbf{w}_i^{(0)})^2 + m^2}}\, w_i^{(1)} \cos\big(w_{ij}^{(0)} x_j + b_i^{(0)}\big), \tag{75}$$

并取密度

$$w^{(1)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_1}^2}{N}\right), \quad w^{(0)} \sim \mathrm{Unif}(B_\Lambda^d), \quad b^{(0)} \sim \mathrm{Unif}[-\pi, \pi], \tag{76}$$

其中 B_Λ^d 是动量空间中半径为 Λ 的球。平移不变性已内建，其功率谱计算为

$$G^{(2)}(p) = \frac{1}{p^2 + m^2}. \tag{77}$$

这就是以神经网络系综实现的 d 维欧氏空间中的自由标量场。请把这一点记到第二天，届时我们将把它形变为 ϕ^4，并利用与该架构相关的形式研究弦。

2.4 神经网络的动力学

已经讨论了两个支柱，接下来是最后一个：*神经网络在梯度下降下如何演化*？我们将先介绍一种称为神经切线核（NTK）的简化，再讨论一个具有均方误差损失的精确可解模型，接着批评 NTK 区域，最后进行标度分析，弥补其核心缺陷并得到特征学习。

设定为使用梯度下降的监督学习：数据为

$$\mathcal{D} = \{(x_\alpha, y_\alpha)\}_{\alpha=1}^{|\mathcal{D}|}, \tag{78}$$

损失为

$$\mathcal{L}[\phi] = \frac{1}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} \ell(\phi(x_\alpha), y_\alpha), \tag{79}$$

参数更新为

$$\frac{d\theta_i}{dt} = -\eta \nabla_{\theta_i} \mathcal{L}[\phi]. \tag{80}$$

定义

$$\Delta(x) = -\frac{\delta \ell(\phi(x), y)}{\delta \phi(x)}, \tag{81}$$

其中 y 是与 x 配对的标签。链式法则将梯度下降改写为

$$\frac{d\theta_i}{dt} = \frac{\eta}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} \Delta(x_\alpha) \frac{\partial \phi(x_\alpha)}{\partial \theta_i}. \tag{82}$$

$\Delta(x)$ 是损失在函数空间中的自然残差。

除非明确取消，本节始终使用 Einstein 求和约定（下文确实会取消）。

2.4.1 神经切线核

这是机器学习理论中的经典内容 [45]。将动力学从参数推到函数上：

$$\frac{d\phi(x)}{dt} = \frac{\partial\phi(x)}{\partial\theta_i}\frac{d\theta_i}{dt} \tag{83}$$

$$= \frac{\eta}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}\Delta(x_\alpha)\Theta(x,x_\alpha), \tag{84}$$

其中

$$\Theta(x,x_\alpha) = \frac{\partial\phi(x)}{\partial\theta_i}\frac{\partial\phi(x_\alpha)}{\partial\theta_i} \tag{85}$$

是神经切线核（NTK）。

推导只用了三行，所以 NTK 显然是基本对象；然而它似乎难以处理，因为它具有：

- **参数依赖性**。它包含对参数的求和，而现代最强大的神经网络有数万亿个参数。
- **时间依赖性**。它依赖参数，而参数沿着轨迹 $\theta(t)$ 随时间演化。
- **随机性**。它继承了 $\theta(0)\sim P(\theta)$ 的随机性。

它还是非局域的，将训练点 x_α 的损失信息传递到测试点 x。这个对象并不容易驾驭。

NTK 之所以出名，在于 $N\to\infty$ 的极限。此时训练进入

$$\text{惰性区域：}\qquad |\theta(t)-\theta(0)| \ll 1, \tag{86}$$

参数数量极多，以至于每个参数几乎不移动，网络可由其线性化很好地逼近 [45, 46]：

$$\lim_{N\to\infty}\phi(x) \simeq \phi_{\text{lin}}(x) := \phi_{\theta_0}(x) + (\theta-\theta_0)_i\left.\frac{\partial\phi(x)}{\partial\theta_i}\right|_{\theta_0}, \tag{87}$$

从而

$$\lim_{N\to\infty}\Theta(x,x') \simeq \Theta(x,x')\big|_{\theta_0}: \tag{88}$$

无限宽 NTK 就是初始化时的 NTK。更好的是，在同一个极限下，大数定律将求和变成期望：

$$\lim_{N\to\infty}\Theta(x,x')\big|_{\theta_0} = \langle\beta_\theta(x,x')\rangle =: \bar{\Theta}(x,x'), \tag{89}$$

其中 $\beta(x,x')$ 可计算，动力学化为

$$\frac{d\phi(x)}{dt} = -\frac{\eta}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}\frac{\delta\ell(\phi(x_\alpha),y_\alpha)}{\delta\phi(x_\alpha)}\bar{\Theta}(x,x_\alpha), \tag{90}$$

它由冻结 *NTK* $\bar{\Theta}$ 支配：确定性的、初始化时可计算的、一经确定便保持不变。这是一个巨大的简化。

但你应该提出异议！动力学 (90) 通过一个固定的核，将训练点 x_α 的损失信息传递给测试点 x。公式中看不到任何参数；由于网络只通过冻结的 $\bar{\Theta}$ 进入，训练期间网络内部发生的一切都不会影响演化。在这一极限下，神经网络**不学习特征**：隐藏层表示保持在初始化附近的一个小邻域。这不可能是深度学习的关键所在。

例子。 通过单层网络的冻结 NTK 看看其机制。对于

$$\phi(x) = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} w_i^{(1)} \sigma\left(\sum_{j=1}^{d} w_{ij}^{(0)} x_j \right), \tag{91}$$

其中求和已显式写出（其中一个求和很重要），其 NTK 为

$$\Theta(x,x') = \sum_i \frac{\partial\phi(x)}{\partial w_i^{(1)}} \frac{\partial\phi(x')}{\partial w_i^{(1)}} + \sum_{ij} \frac{\partial\phi(x)}{\partial w_{ij}^{(0)}} \frac{\partial\phi(x')}{\partial w_{ij}^{(0)}} \tag{92}$$

$$= \frac{1}{N} \sum_{i=1}^{N} \Bigg(\sum_{j,l=1}^{d} \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} x_l') \tag{93}$$

$$+ \sum_{j=1}^{d} x_j x_j' w_i^{(1)} w_i^{(1)} \sigma'(w_{ij}^{(0)} x_j) \sigma'(w_{ij}^{(0)} x_j') \Bigg) \tag{94}$$

$$=: \frac{1}{N} \sum_i \beta_i(x,x'). \tag{95}$$

仔细看：对 i 的求和遍历同一个对象 $\beta_i(x,x')$ 的 N 个独立同分布副本，随机性来自 i 方向的参数抽样。大数定律给出 $N \to \infty$ 时

$$\bar{\Theta}(x,x') = \langle \beta_i(x,x') \rangle, \tag{96}$$

其中不对 i 求和。我们强调：$N \to \infty$ 的 *NTK* 是确定性的：它只依赖 $P(\theta)$，而不依赖具体抽样。只要能用闭式计算这一期望，支配动力学的核就始终是精确已知的。

2.4.2 一个精确可解模型

将冻结 NTK 动力学具体化为均方误差损失：

$$\ell(\phi(x), y) = \frac{1}{2}(\phi(x) - y)^2, \tag{97}$$

则式 (90) 变为

$$\frac{d\phi(x)}{dt} = -\frac{\eta}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} (\phi(x_\alpha) - y_\alpha) \bar{\Theta}(x, x_\alpha). \tag{98}$$

这个线性常微分方程可精确求解：

$$\phi_t(x) = \phi_0(x) + \bar{\Theta}(x, x_\alpha) \bar{\Theta}(x_\alpha, x_\beta)^{-1} \left(\mathbb{1} - e^{-\frac{\eta}{|\mathcal{D}|} \bar{\Theta} t} \right)_{\beta\gamma} (y_\gamma - \phi_0(x_\gamma)), \tag{99}$$

唯一的计算开销是对 $|\mathcal{D}| \times |\mathcal{D}|$ 矩阵 $\bar{\Theta}(x_\alpha, x_\beta)$ 求逆，其复杂度为 $O(|\mathcal{D}|^3)$。该解在函数空间中描绘了一条从 ϕ_0 出发到达下式的路径：

$$\phi_\infty(x) = \phi_0(x) + \bar{\Theta}(x, x_\alpha) \bar{\Theta}(x_\alpha, x_\beta)^{-1} (y_\beta - \phi_0(x_\beta)). \tag{100}$$

这就是**核回归**，一种机器学习中的常用方法。通常人们手动选择核；在这里，$N \to \infty$ 的梯度下降训练就是核回归，其核 $\bar{\Theta}$ 由网络架构确定。

在训练点上，网络实现了**记忆**：

$$\phi_\infty(x_\alpha) = y_\alpha, \qquad \forall\alpha. \tag{101}$$

在测试点上，它通过固定的核传递训练点残差，进行插值。假设 $\langle\phi_0\rangle = 0$（标准初始化满足此条件），对初始化取平均：

$$\mu_\infty(x) := \langle\phi_\infty(x)\rangle = \bar{\Theta}(x, x_\alpha)\bar{\Theta}(x_\alpha, x_\beta)^{-1} y_\beta. \tag{102}$$

让我们用文字说明这些**值得注意的事实**：

- $\mu_\infty(x)$ 是无穷多个无限宽网络经无穷长时间训练后的平均预测，即我们在问题设定中提出的问题的答案。
- 如果 ϕ_0 是从高斯过程中抽样的，ϕ_∞ 也是如此，其均值为 $\mu_\infty(x)$；协方差参见文献 [46]。

2.4.3 特征学习

冻结 NTK 是一个可处理的玩具模型，但它有一个主要缺点：它不学习特征。本节将更一般地研究学习动力学，重点是明智地选择 N 的标度，使得梯度下降期间能够非平凡地学习特征。为此，我们将构造三项性质：特征（预激活）在初始化时有限；预测在有限时间内演化；特征在有限时间内演化。

本节比其他节更密集，因此如果读者被细节淹没，我建议记住我们的目标是实现这三条原则。下面我遵循 Pehlevan 和 Bordelon 的讲义 [47]，并略微改变记号以匹配本讲义其余部分；更多细节参见他们的讲义，我所使用的那些讲义中的原始文献见 [48, 49]，有关特征学习的相关工作见 [50, 51]。

我们研究一个具有 L 层、宽度为 N 的深度前馈网络，整体上它是映射

$$\phi : \mathbb{R}^D \to \mathbb{R} \tag{103}$$

（注意输入维度为 D；d 留待下文使用），并递归地定义为

$$\phi(x) = \frac{1}{\gamma_0 N^d} z^{(L)}(x), \tag{104}$$

$$z^{(L)}(x) = \frac{1}{N^{a_L}} w_i^{(L)}\, \sigma(z_i^{(L-1)}(x)), \tag{105}$$

$$z_i^{(\ell)}(x) = \frac{1}{N^{a_\ell}} W_{ij}^{(\ell)} \sigma(z_j^{(\ell-1)}(x)), \tag{106}$$

$$z_i^{(1)}(x) = \frac{1}{N^{a_1}\sqrt{D}} W_{ij}^{(1)} x_j. \tag{107}$$

本节始终使用 Einstein 求和约定（除非另有说明），所有拉丁指标都取值于 $\{1, \ldots, N\}$，但第一层中的指标 j 除外，该指标取值于 $\{1, \ldots, D\}$。参数按以下分布抽取：

$$w_i^{(\ell)} \sim \mathcal{N}\left(0, \frac{1}{N^{b_L}}\right), \qquad W_{ij}^{(\ell)} \sim \mathcal{N}\left(0, \frac{1}{N^{b_\ell}}\right). \tag{108}$$

我们令学习率按如下方式标度：

$$\eta = \eta_0 \gamma_0^2 N^{2d-c}, \tag{109}$$

其中 γ_0, η_0 是 $O(1)$ 的常数。这些 z 是预激活（特征）；希腊下标用于简写输入，例如 $z_\alpha^{(\ell)} := z^{(\ell)}(x_\alpha)$。

我们拥有一个标准的 MLP，但已将对于 N 标度的未知性参数化，由参数 (a_ℓ, b_ℓ, c, d) 控制。我们将利用这一自由度设置若干合理的**目标**：

- **初始化时预激活有限**。对所有 ℓ，$z^{(\ell)} \sim O_N(1)$。
- **有限时间内学习**。$d\phi(x)/dt \sim O_N(1)$。
- **有限时间内学习特征**。对所有 ℓ，$dz^{(\ell)}/dt \sim O_N(1)$。

这些约束有一个单参数解族；再增加一个关于学习率的要求，即可完全确定解。我们逐一讨论这些约束。

预激活有限。 由于权重的均值为零，显然有

$$\langle z_\alpha^{(\ell)} \rangle = 0 \qquad \forall \ell. \tag{110}$$

我们还必须计算协方差。对于第一个预激活，有

$$\langle z_{i\alpha}^{(1)} z_{j\beta}^{(1)} \rangle = \frac{1}{DN^{2a_1}} \langle W_{im}^{(1)} W_{jn}^{(1)} \rangle x_{m\alpha} x_{n\beta} = \delta_{ij} \frac{1}{DN^{2a_1+b_1}} x_{m\alpha} x_{m\beta}. \tag{111}$$

对更高层 ℓ 进行类似计算得到

$$\langle z_{i\alpha}^{(\ell)} z_{j\beta}^{(\ell)} \rangle = \frac{1}{N^{2a_\ell}} \langle W_{im}^{(\ell)} W_{jn}^{(\ell)} \rangle \, \langle \sigma(z_{m\alpha}^{(\ell-1)}) \sigma(z_{m\beta}^{(\ell-1)}) \rangle \tag{112}$$

$$= \delta_{ij} \frac{1}{N^{2a_\ell+b_\ell-1}} \frac{1}{N} \langle \sigma(z_{m\alpha}^{(\ell-1)}) \sigma(z_{m\beta}^{(\ell-1)}) \rangle \tag{113}$$

$$= \delta_{ij} \frac{1}{N^{2a_\ell+b_\ell-1}} \langle \Phi_{\alpha\beta}^{(\ell-1)} \rangle, \tag{114}$$

其中

$$\Phi_{\alpha\beta}^{(\ell)} := \frac{1}{N} \sigma(z_{m\alpha}^{(\ell)}) \sigma(z_{m\beta}^{(\ell)}) \tag{115}$$

是一个特征核。我们正在通过归纳法证明预激活为 $O_N(1)$，所以在此阶段可以假设 $z^{(\ell-1)} \sim O_N(1)$；因此 $\Phi^{(\ell-1)} \sim O_N(1)$，因为它是 N 个 $O_N(1)$ 量 $\sigma(z_{m\alpha}^{(\ell-1)})$ 的平均值。由此，条件

$$2a_1 + b_1 = 0, \qquad 2a_\ell + b_\ell = 1 \quad \forall \ell > 1 \tag{116}$$

保证预激活 $z^{(\ell)}$ 为 $O_N(1)$；从经验上说，这是训练表现良好所需要的。

顺便指出：在 $N \to \infty$ 极限下，特征核渐近趋于确定性对象，类似于我们已经看到的冻结 NTK 行为；中间层预激活 $z_\alpha^{(\ell)}$ 也服从高斯分布。因此，在该极限下，随机初始化神经网络的统计由一列广义自由场论描述，关联函数按照递推关系沿网络传播；例如参见文献 [52, 46]。

有限时间内学习。 与 NTK 的推导类似，有

$$\frac{d\phi(x)}{dt} = \frac{\eta}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}\Delta(x_\alpha)\frac{\partial\phi(x_\alpha)}{\partial\theta_i}\frac{\partial\phi(x)}{\partial\theta_i}. \tag{117}$$

我们有

$$\frac{d\phi(x)}{dt}\sim O_N(1) \quad \leftrightarrow \quad \frac{\gamma_0^2 N^{2d}}{N^c}\frac{\partial\phi(x_\alpha)}{\partial\theta_i}\frac{\partial\phi(x)}{\partial\theta_i}\sim O_N(1). \tag{118}$$

进行简短但繁琐的计算，运用链式法则并区分不同类型的层，得到

$$\begin{aligned}\frac{\eta_0\gamma_0^2 N^{2d}}{N^c}\frac{\partial\phi(x_\alpha)}{\partial\theta_i}\frac{\partial\phi(x)}{\partial\theta_i} = \frac{1}{N^c}\Bigg[&\frac{1}{N^{2a_L-1}}\Phi^{(L-1)}_{\mu\nu}\\ &+\sum_{\ell=2}^{L-1}\frac{1}{N^{2a_\ell-1}}G^{(\ell)}_{\alpha x}\Phi^{(\ell-1)}_{\alpha x}+\frac{1}{N^{2a_1}}G^{(1)}_{\alpha x}\Phi^{(0)}_{\alpha x}\Bigg],\end{aligned} \tag{119}$$

其中

$$G^{(\ell)}_{\mu\nu} = \frac{1}{N}g^{(\ell)}_{i\mu}g^{(\ell)}_{i\nu}, \qquad g^{(\ell)}_{i\mu} = \sqrt{N}\,\frac{\partial z^{(L)}_\mu}{\partial z^{(\ell)}_{i\mu}} \tag{120}$$

自然地出现在对各层使用链式法则的过程中；下标中的 x 代指任意输入 x。进一步计算 [47] 表明 $g, G\sim O_N(1)$。由于我们已说明特征核也是 $O_N(1)$，因此如果

$$2a_1+c=0, \qquad 2a_\ell+c=1 \quad \forall\ell>1, \tag{121}$$

就有 $d\phi(x)/dt\sim O_N(1)$，即预测在有限时间内演化，从而学习在有限时间内发生。

特征在有限时间内演化。 最后，我们需要特征发生演化。对第一层计算得到

$$\frac{dz^{(1)}_{i\mu}}{dt} = \frac{1}{N^{a_1}\sqrt{D}}\frac{dW_{ij}}{dt}x_{j\mu} = \frac{1}{N^{2a_1+c-d+1/2}}\frac{\eta_0\gamma_0}{|\mathcal{D}|}\sum_{\nu=1}^{|\mathcal{D}|}\Delta_\nu g^{(1)}_{i\nu}\Phi^{(0)}_{\mu\nu}, \tag{122}$$

其中对 N 的依赖仅来自指数。根据式 (121)，要使 $dz^{(1)}/dt\sim O_N(1)$，必须要求

$$d=\frac{1}{2}, \tag{123}$$

这一约束实际上对所有 $dz^{(\ell)}/dt$ 都成立。注意，**若 $d<\frac{1}{2}$，就没有特征学习**；这特别适用于 $d=0$ 的 NTK 状态。

约束总结。 综合以上结果，通过要求预激活有限、预测和特征在有限时间内演化，我们得到约束

$$2a_1+b_1=0, \tag{124}$$

$$2a_\ell+b_\ell=1 \quad \forall\ell>1, \tag{125}$$

$$2a_1+c=0, \tag{126}$$

$$2a_\ell+c=1 \quad \forall\ell>1, \tag{127}$$

$$d=\frac{1}{2}. \tag{128}$$

这些约束由依赖 $a \in \mathbb{R}$ 的单参数族求解：

$$(a_\ell, b_\ell, c_\ell) = (a, 1-2a, 1-2a) \quad \forall \ell > 1, \tag{129}$$

$$(a_1, b_1, c_1) = \left(a - \frac{1}{2}, 1-2a, 1-2a\right). \tag{130}$$

如果进一步要求 $\eta \sim O_N(N^{2d-c})$ 为 $O_N(1)$，从而在扩大网络规模时不必改变学习率，那么 $c = 1$ 被固定，且解唯一。这种标度称为*最大更新参数化*，或 μP [48]。它不只是理论：实践中扩大模型规模时，正是借此保留特征学习行为。

3 第二天：神经网络场论

第一天我们不断遇到场论：网络系综的关联函数、无限宽度下的广义自由场，以及 $1/N$ 相互作用。那些讲座的目标是利用物理研究机器学习。

今天我们反过来问，神经网络能否提供一种研究场论的新方法。

3.1 NN-FT 基础

3.1.1 什么是场论？

让我们以一个简单得令人不安的问题开始今天的讲座：什么是场论？场论的一些基本要素包括：

- **场**：某个函数空间中的函数，或者更一般地，分布或适当纤维丛的截面。
- 这些场的**关联函数**：

$$G^{(n)}(x_1,\dots,x_n)=\langle\phi(x_1)\dots\phi(x_n)\rangle. \tag{131}$$

你很可能希望在这个列表中加入其他东西，但请暂且搁置。有了这些要素，场论就是一个函数系综以及一种计算其关联函数的方法。我们设想使用配分函数完成计算：

$$Z[J]=\left\langle e^{\int d^dx\,J(x)\phi(x)}\right\rangle, \tag{132}$$

目前不指定 $\langle\cdot\rangle$ 的定义。标准定义由 Feynman 给出：

$$Z[J]=\int\mathcal{D}\phi\,e^{-S[\phi]+\int d^dx\,J(x)\phi(x)}, \tag{133}$$

它需要作用量 $S[\phi]$ 来定义函数上的密度。但指定神经网络时，我们指定的并不是作用量。网络数据 $(\phi_\theta,P(\theta))$ 定义的是

$$Z[J]=\int d\theta\,P(\theta)e^{\int d^dx\,J(x)\phi_\theta(x)}. \tag{134}$$

这是定义场论的两种不同方式。当它们对于同一理论均存在时，就得到统计性质的对偶描述，如第一天的 NNGP 对应关系。

关键是式 (134) 可以独立成立：即使不知道作用量，我们也能够定义、研究并利用场论 $(\phi_\theta,P(\theta))$ 进行计算。特别地，关联函数可以从参数空间计算；在某些相互作用理论中，它们可以通过这种方法精确计算。下面记录贯穿今天讲座的定义。

定义 3.1 (神经网络场论)**.** *NN-FT 由架构 $\phi_\theta:\mathbb{R}^d\to\mathbb{R}^D$ 和参数密度 $P(\theta)$ 给出，并配有参数空间配分函数 (134) 及其关联函数。*

可以通过加入指标 [42] 或使用 Grassmann 值神经网络 [53] 等方式，将此推广到其他类型的场。要点是，理论由一个架构和其参数上的密度定义。

现在来回应你的异议。你希望场论的定义包含某个 X，其中

$$X\in\{\text{量子性},\text{拉格朗日形式},\text{对称性},\text{局域性},\dots\}. \tag{135}$$

困难在于，对每一个这样的 X，都存在一个活跃的物理学家群体，他们愿意舍弃它：有些统计场论并非良好量子理论的 Wick 旋转，有些理论没有已知拉格朗日量，有些理论没有对称性，也有非局域理论等。

因此我保留最小定义（场及关联函数），将其他一切都转化为构造问题：*能否设计定义理论的数据，得到具有 X 的场论？*无论定义数据是 $S[\phi]$ 还是 $(\phi_\theta, P(\theta))$，这是一个自然的问题。过去几年 NN-FT 的许多进展，就是逐个针对不同的 X 回答这个问题；下文将给出相关文献。

3.1.2 按需构造自由理论

第一个构造目标是自由理论，第一天我们已经做了相关工作。形式为

$$\phi(x) = \frac{1}{\sqrt{N}} \sum_i w_i \varphi_i(x) \tag{136}$$

且神经元独立同分布的架构，根据中心极限定理在 $N \to \infty$ 时变为高斯形式（广义自由场）；具有谱塑形函数 F 的欧氏不变输入层则使我们能调出所需传播子。一个关键结果是 Scalar-net (75)，其功率谱为

$$G^{(2)}(p) = \frac{1}{p^2 + m^2}, \tag{137}$$

即 d 维自由标量场，由隐藏层权重在动量球中均匀分布的无限宽网络系综实现。

一般方法是：为了构造自由 NN-FT，选择适用中心极限定理的架构和密度，然后按需要塑造 $G^{(2)}$。这一构造自由标量场的方法（机器学习中称为随机 Fourier 特征）的变体将作为弦的世界面玻色子和 XY 模型的自旋波，在今天再次出现。

3.1.3 量子场论

我们一直坚持在欧氏时空中讨论。这些理论在什么意义上可以是量子的？在量子场论课程中，人们进行正则量子化和 Wick 旋转，量子属性是显然的。这里我们既没有 Hilbert 空间，也没有作用量，只有欧氏关联函数，因此必须问：*给定欧氏关联函数，能否将理论延拓为性质良好的 Lorentz 量子理论？*这是构造性场论的奠基问题，并有一个著名的回答 [54]。

定理 3.2 (Osterwalder–Schrader 重建)**.** *一组作为缓增分布的欧氏关联函数，如果满足欧氏不变性、置换对称性、反射正性与簇分解，就可解析延拓为满足 Wightman 公理的幺正 Lorentz 量子场论。*

具体条件为：

- 关联函数的**欧氏不变性**，延拓后变为 Poincaré 不变性。
- $G^{(n)}(x_1, \dots, x_n)$ 对其各自变量的**置换不变性**。
- **反射正性**：选取欧氏时间 τ，令 $R(x)$ 表示关于 $\tau = 0$ 的反射，有

$$G^{(2n)}(x_1, \dots, x_n, R(x_1), \dots, R(x_n)) \geq 0, \tag{138}$$

这是幺正性和正范数态在欧氏空间中的表现。（此式是必要形式；详细讨论见文献 [54, 55]。）

- **簇分解**：在无穷远分离时，连通关联函数消失。

若一对 $(\phi_\theta, P(\theta))$ 的关联函数通过这些条件，就定义了一个神经网络量子场论 [44]，其意义是 O-S 公理确定一个量子场论。NN-FT 中置换不变性自动成立；欧氏不变性可以通过第一天的吸收机制构造；反射正性和簇分解在一些例子中成立 [44, 35]，但量子力学情形 [56] 以外的系统构造仍是开放问题。

3.1.4 对称性

第一天的吸收机制 [42] 是实现对称性的一种简单方法：

1. **作用**。对任意 $g \in G$，在网络上实现 g 的作用。
2. **吸收**。重定义参数，吸收 g 的作用。
3. **不变性**。检查 $d\theta\, P(\theta)$ 不发生变换。

Cos-net 通过这种方法实现了欧氏群。下文近期结果将给出两种升级：可以构造共形及 Virasoro 对称性 [57, 58, 59]；吸收机制也已发展成参数空间中 Ward 恒等式、Schwinger–Dyson 方程与反常的完整理论 [60]。NN-FT 现在也通过 Grassmann 值参数包含费米子和超对称 [53]，这将在今天给出鬼场。

3.1.5 相互作用

自由理论来自中心极限定理，相互作用则来自对它的破坏。第一天的第一个途径是有限 N，它产生 $O(1/N)$ 的连通关联函数。第二个途径，即独立性破缺，也可以显式实现。假设 $(\phi_\theta, P(\theta))$ 是具有高斯配分函数的 NNGP：

$$Z_G[J] = \int d\theta\, P(\theta) e^{\int d^d x\, J(x)\phi_\theta(x)}. \tag{139}$$

插入与任意局域势 $V(\phi)$ 对应的算符：

$$Z[J] = \int d\theta\, P(\theta) e^{-\int d^d x\, V(\phi_\theta(x))} e^{\int d^d x\, J(x)\phi_\theta(x)} \tag{140}$$

$$=: \int d\theta\, \widetilde{P}(\theta) e^{\int d^d x\, J(x)\phi_\theta(x)}. \tag{141}$$

架构方程使我们能够将抽象插入换成参数的具体函数，从而定义形变后的密度：

$$\widetilde{P}(\theta) = P(\theta) e^{-\int d^d x\, V(\phi_\theta(x))}. \tag{142}$$

要点是，由于 ϕ_θ 由显式架构给定，代入后得到一个混合参数的具体函数。一般而言，这种形变破坏了中心极限定理所用的统计独立性，从而产生相互作用。

对于 ϕ^4 理论，在 Scalar-net 配分函数中插入

$$e^{-\frac{\lambda}{4!}\int d^d x\, \phi_\theta(x)^4}, \tag{143}$$

使式 (76) 形变为具有相关性的密度（对于该具体架构，需要红外正则化）。完整处理见文献 [35]。

综上，相互作用的机制是通过 $1/N$ 修正或独立性破缺违反中心极限定理的假设。顺便指出，在概率量子场论界，这种机制（形变高斯密度、保持架构）正是构造 Liouville 理论的方法 [61]；这一主题也是 Simons 概率路径量子场论合作项目 [62] 的研究对象。

3.2 近期结果

近期出现了许多利用 NN-FT 研究物理的成果，尤其是 2025 年 11 月以来。其中包括共形对称性 [57]、缺陷共形场论 [59]、Virasoro 对称性 [58]、费米子与超对称 [53, 63]、重整化群流 [64]、Transformer 架构 [65]、关于实现相同 GP 极限的不同理论的最优性结果 [66]，以及本节的结果：普适性 [67]、Liouville 理论 [67]、玻色弦 [68]、拓扑扇区与 Kosterlitz–Thouless 相变 [69]，以及反常 [60]。

3.2.1 普适性

第一天我们讨论了神经网络的表达能力，即它们能否表示或逼近给定类型的函数。答案是肯定的，例如可由 Cybenko 的普适逼近定理确立。

将这一表达能力问题自然地推广到 NN-FT，我们问：*哪些场论允许 NN-FT 描述？*要回答这个问题，必须充分精确地说明我们所说的场论是什么意思。对于使用构造性量子场论工具描述的标量场论，答案是 NN-FT 具有普适性 [67]；本节将对此作出精确定义。

首先，我们所说的场论是什么意思？已知场论中的场比函数更“粗糙”。为了理解这一点，回忆动能项 $\partial_\mu\phi\partial^\mu\phi$ 在格距为 a 的格点理论中写成

$$a^d\left(\frac{\phi(x+an)-\phi(x)}{a}\right)^2, \tag{144}$$

其中 n 是格向量。要取连续极限，需要

$$\phi(x+an)-\phi(x)\sim a^{1-d/2}, \tag{145}$$

使动能项在 $a\to 0$ 时保持有限。在 $d=1$ 时，这是 Brownian 粗糙性（连续但处处不可微）；在 $d\geq 2$ 时，典型构型根本不是函数，而是*缓增 Schwartz 分布*，即 $\mathcal{S}'(\mathbb{R}^d)$ 的元素。相应地，构造性场论将欧氏量子场论定义为 $\mathcal{S}'(\mathbb{R}^d)$ 上的概率分布；如果希望将其延拓为 Lorentz 符号下的幺正理论，则在此基础上加入 OS 公理。

进一步细化关于 NN-FT 普适性的问题，我们问：*$\mathcal{S}'(\mathbb{R}^d)$ 上的所有概率分布，是否都允许以数据 $(\phi_\theta, P(\theta))$ 给出 NN-FT 描述？*要回答这个问题，应明确“神经网络描述”的含义。最简洁的图景是两个概率空间和它们之间的一个映射，取自文献 [67]：

$$\underset{\text{神经网络参数}}{(\mathbb{R}^{\mathbb{N}},\mathcal{B}(\mathbb{R})^{\otimes\mathbb{N}},P)}\xrightarrow{\phi_\theta\,(\text{架构})}\underset{\text{场论}}{(\mathcal{S}'(\mathbb{R}^d),\mathcal{B}(\mathcal{S}'),P_\phi)}$$

两端都是**概率空间**，它们之间的箭头就是架构：

- **场论**（右侧）是场构型空间 $\mathcal{S}'(\mathbb{R}^d)$ 上的概率分布 P_ϕ；
- **神经网络参数**（左侧）是参数 $\theta\in\mathbb{R}^{\mathbb{N}}$ 上的概率分布 P；
- **架构** ϕ_θ 将参数映射为场构型，使参数密度的推前满足 $(\phi_\theta)_*P=P_\phi$。

从这一视角看，NN-FT 是将参数密度通过架构推前所得到的场论；普适性问题是每个场论能否以这种方式实现。

答案是肯定的，理由清楚：两端都是标准 Borel 空间，而 Borel 同构定理保证任意两个这样的空间之间存在同构。也就是说，存在同构

$$\phi_\theta : \mathbb{R}^{\mathbb{N}} \xrightarrow{\sim} \mathcal{S}'(\mathbb{R}^d), \tag{146}$$

因此给定 P_ϕ，存在 P 使得 $(\phi_\theta)_* P = P_\phi$。可以将 Borel 同构本身作为架构。所以 [67]：

定理 3.3 (NN-FT 的普适性)**.** *$\mathbb{R}^d$ 上缓增分布空间的任何概率分布（特别是构造性意义下的任何欧氏量子场论，无论是否满足 OS 公理）都存在具有可数个参数的神经网络描述 $(\phi_\theta, P(\theta))$。*

我们强调，由 Borel 同构保证的架构与许多机器学习架构不同，它在参数与函数之间是一一对应的。当神经元取为函数空间的基 φ_i 时便是这种情况。

3.2.2 Liouville 理论

Liouville 理论是一个二维相互作用共形场论，其作用量为

$$S = \int_\Sigma d^2x\,\sqrt{g}\left(\frac{1}{4\pi}\partial^\mu\phi\,\partial_\mu\phi + \frac{Q}{4\pi}R\phi + \mu e^{2b\phi}\right), \tag{147}$$

其中背景荷 $Q = b + 1/b$，且 $c_L = 1 + 6Q^2$。初级场是顶点算符 $V_\alpha = :e^{2\alpha\phi}:$，其 $\Delta_\alpha = \alpha(Q-\alpha)$；共形对称性将三点函数固定为以下形式，仅剩结构常数待定：

$$\langle V_{\alpha_1}(x_1)V_{\alpha_2}(x_2)V_{\alpha_3}(x_3)\rangle = \frac{C(\alpha_1,\alpha_2,\alpha_3)}{|x_{12}|^{2\Delta_{123}}|x_{13}|^{2\Delta_{132}}|x_{23}|^{2\Delta_{231}}}, \tag{148}$$

其中 $\Delta_{ijk} = \Delta_i + \Delta_j - \Delta_k$。结构常数由 DOZZ 公式给出 [70, 71]：记 $\gamma(x) = \Gamma(x)/\Gamma(1-x)$、$s = (\alpha_1+\alpha_2+\alpha_3 - Q)/b$，以及 Zamolodchikov 特殊函数 Υ_b，则

$$C = \Big(\pi\mu\,\gamma(b^2)b^{2-2b^2}\Big)^{-s}\frac{\Upsilon_b'(0)\prod_{i=1}^3\Upsilon_b(2\alpha_i)}{\Upsilon_b(\sum_i\alpha_i - Q)\prod_{i=1}^3\Upsilon_b\Big(\sum_j\alpha_j - 2\alpha_i\Big)}, \tag{149}$$

其中当 $0 < \mathrm{Re}\,z < Q$ 时，

$$\log\Upsilon_b(z) = \int_0^\infty\frac{dt}{t}\left[\left(\frac{Q}{2}-z\right)^2 e^{-t} - \frac{\sinh^2\left[\left(\frac{Q}{2}-z\right)\frac{t}{2}\right]}{\sinh\frac{bt}{2}\,\sinh\frac{t}{2b}}\right]. \tag{150}$$

这个无理 c 的结构常数是我们的目标。

概率量子场论界近期的工作 [61]（介绍参见 [72]）确立了 Liouville 理论是一个严格定义的相互作用理论；事实表明，这一构造实际上是一个 NN-FT。其架构是一个零模加实球谐函数：

$$\phi_\theta = c + \sum_{\ell=1}^{L}\sum_{m=-\ell}^{\ell} a_{\ell,m}Y_{\ell,m}, \tag{151}$$

参数为 $\theta = \{c, a_{\ell,m}\}$。球面上的自由场由以下高斯参数抽样得到：

$$a_{\ell,m} \sim \mathcal{N}\left(0, \frac{4\pi}{\ell(\ell+1)}\right). \tag{152}$$

相互作用按之前介绍的方式进入：形变参数密度。

值得注意的是，在 NN-FT 中，所有 Liouville 相互作用都可以加载到零模上。具体而言，两个相互作用项都化为常数 c 的函数；在给出简洁的 NN-FT 答案前，我们先说明理由。圆球面上 R 是常数，因此曲率耦合与涨落的积分为零（当 $\ell \geq 1$ 时，$\int_{S^2}\sqrt{g}\,RY_{\ell,m} = 0$），留下 $\int_{S^2}\sqrt{g}\,\frac{Q}{4\pi}R\phi = 2Qc$，它完全来自零模。与此同时，指数项分解为 $e^{2b\phi} = e^{2bc}e^{2bX}$，因此它对零模的唯一依赖是乘在涨落部分 $M_X = \mu\int_{S^2}\sqrt{g}\,{:}e^{2bX}{:}$ 前面的标量因子 e^{2bc}。故两项都完全位于 c 中（以及顶点因子 $e^{2\alpha_i c}$），所以只有零模的密度发生形变。写作 $t = e^{2bc}$，密度分解为

$$P(\theta) = P(t \mid a_{\ell,m})P(a_{\ell,m}), \tag{153}$$

其中网络参数为 $\theta = \{t, a_{\ell,m}\}$，零模的条件密度为

$$P(t \mid a_{\ell,m}) \propto t^{s-1}\exp\bigl(-M_X(a_{\ell,m})t\bigr), \qquad s = \frac{\sum_i \alpha_i - Q}{b}, \tag{154}$$

这里

$$M_X = \mu\int_{S^2} d^2x\sqrt{g}\,{:}e^{2b\sum a_{\ell,m}Y_{\ell,m}}{:} \tag{155}$$

是所谓的高斯乘性混沌。非零模仍是独立的高斯变量；所有统计依赖性和相互作用都位于零模如何以它们为条件。指数 s 汇集了零模出现的三个位置：曲率耦合（非零模永远不感受到它，因为圆球面上 $\int\sqrt{g}\,Y_{\ell,m}R = 0$）、顶点算符插入和指数相互作用。

接下来的计算 [67] 是参数空间中实实在在的 Monte Carlo：对 $a_{\ell,m}$ 采样，用平滑后的系综方差执行正规序，将球面像素化以计算 M_X，按其条件密度对 t 采样，再取平均。

在 $L = 30$ 时，非微扰数值计算在一系列 b 和 α_3 值下与 DOZZ 公式在百分之几的水平上一致（图 3）；独立实验给出的误差条小于图中标记。接近 DOZZ 出现零点的 Seiberg 界 $\alpha \leq Q/2$ 时，一致性变差，这正符合预期。

3.2.3 玻色弦

我们身处弦论学校，因此应当提出问题：*弦论是 NN-FT 吗？*对于玻色弦，答案是肯定的 [68]：规范固定后的世界面理论可以由无限宽网络系综实现，并允许计算 Virasoro–Shapiro 和 Veneziano 振幅。（NN-FT 中的世界面 Virasoro 对称性见相关工作 [58]。）

自由玻色子。 平面 $z = x_1 + ix_2$ 上的嵌入场 $X^\mu(z,\bar z)$（$\mu = 1,\dots,D$）取以下架构：

$$X^\mu(z) = \frac{C}{\sqrt{N}}\sum_{i=1}^{N}\frac{a_i^\mu}{|W_i|}\cos\left(\frac{1}{2}(W_i z + \bar W_i\bar z) + c_i\right), \tag{156}$$

其中参数独立同分布地抽样：

$$a_i^\mu \sim \mathcal{N}(0,\sigma_a^2), \quad c_i \sim \mathrm{Unif}[-\pi,\pi], \quad W_i \sim \mathrm{Unif}(B_\Lambda^2 \setminus B_\epsilon^2). \tag{157}$$

复隐藏权重 W_i 在动量空间的环域上均匀分布：Λ 是紫外截止，ϵ 是红外截止。这是第一天的欧氏不变层在二维世界面上的形式，谱塑形因子为 $1/|W_i|$。对参数取平均，两点函数是一个 Bessel 积分，其结果为

$$\langle X^\mu(z)X^\nu(w)\rangle = \alpha'\delta^{\mu\nu}\left[-\log r + \log\frac{2\Lambda}{\epsilon e^\gamma} + \cdots\right], \quad r = |z-w|, \tag{158}$$

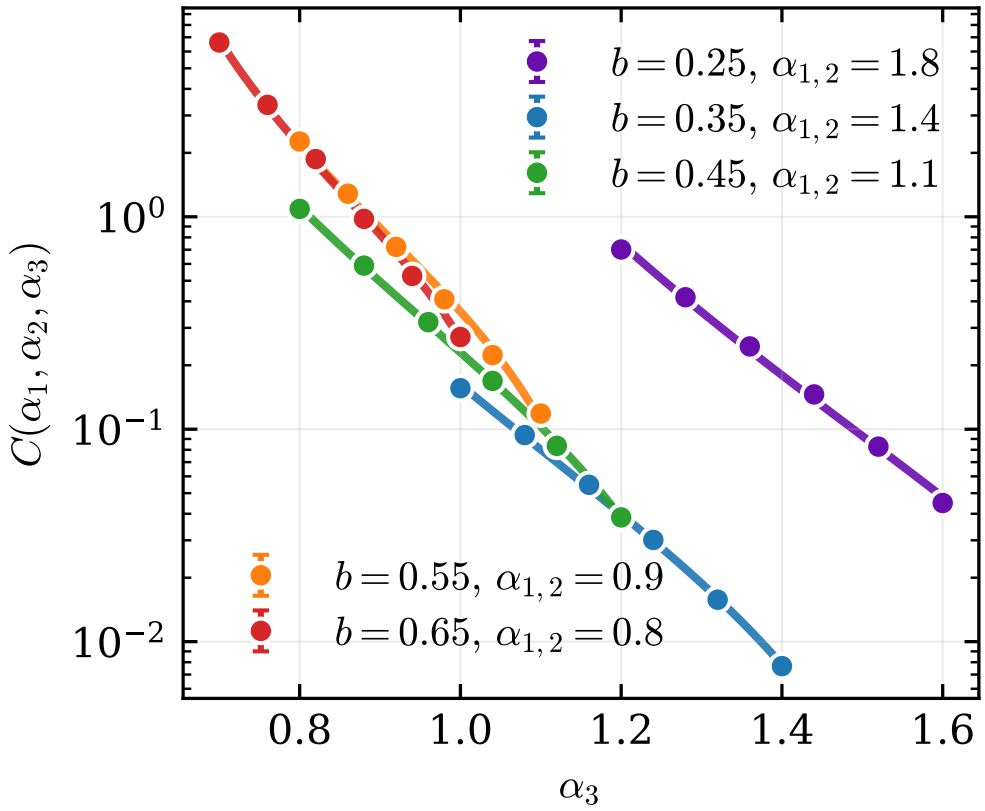


图 3: 从神经网络关联函数得到的 Liouville 结构常数 $C(\alpha_1, \alpha_2, \alpha_3)$（点；固定 $\alpha_1 = \alpha_2$ 并改变 α_3，对应若干 b 值）与精确 DOZZ 公式（实线）比较，后者落在所有误差条内。NN-FT 计算使用 $L = 30$ 的球谐函数，进行 10 次实验，每次运行 50,000 次，球面以 100×200 个点像素化；误差条（实验间方差）小于标记 [67]。

当 $1/\Lambda \ll r \ll 1/\epsilon$ 时得到自由玻色子的对数形式，即环域上 $G^{(2)}(p) = 2\pi\alpha'\delta^{\mu\nu}/p^2$。由中心极限定理，$N \to \infty$ 的系综是恰具有这一传播子的高斯理论：规范固定的 Polyakov 玻色子由它的统计性质定义，完全不必写出世界面作用量。世界面欧氏不变性来自 (W, c) 的密度，时空旋转不变性来自 a^μ 的高斯分布。还可加入零模 $X_0^\mu \sim \mathcal{N}(0, \sigma_0^2)$。

令归一化常数 $C = 1$ 并匹配系数，得到

$$\alpha' = \frac{\sigma_a^2}{\Lambda^2 - \epsilon^2}. \tag{159}$$

环域半径是正则化参数；此构造中唯一的物理调节量是 σ_a，而玻色弦唯一的物理参数是 α'。其他架构也可以实现自由玻色子，其输出权重方差扮演类似角色。

鬼场。 *bc* 系统需要反对易场，而 NN-FT 现在可以提供它们 [53]：取相同的随机特征架构，但采用 Grassmann 值输出权重 β_k, χ_k 以及 Grassmann 高斯密度 $P \propto \exp(\beta_k\chi_k/\sigma^2)$，于是 Berezin 积分给出 $\langle\beta_k\chi_l\rangle = \sigma^2\delta_{kl}$。适当安排相位后，参数空间平均产生

$$\langle b(z)c(w)\rangle = \frac{1}{z-w} + \cdots, \tag{160}$$

这就是标准鬼场传播子，修正在 Λr 很大时消失；详见文献 [68]。具有 Grassmann 参数的网络系综构成了世界面鬼场系统。

参数空间中的振幅。 既然已经实现自由玻色子与 *bc* 鬼场，就已实现规范固定的玻色弦的基本世界面场，应该可以计算振幅。

四快子闭弦振幅是球面上的规范固定关联函数：

$$\mathcal{A}^{(4)} = \frac{1}{g_s^2}\frac{1}{\mathrm{Vol}(SL(2,\mathbb{C}))}\left\langle \prod_{i=1}^{4} V(p_i)\right\rangle, \quad V(p) = g_s\mathcal{Z}(p)\int d^2z\, e^{ip\cdot X(z)}, \tag{161}$$

其中期望是参数空间期望。展开后，振幅是对网络参数的有限维积分：

$$\begin{aligned}\mathcal{A}^{(4)} = \frac{g_s^2}{\mathrm{Vol}(SL(2,\mathbb{C}))}\int [d\mu_X]\left(\prod_{\alpha=1}^{4} d^2z_\alpha\right)\\ \times\, \mathcal{Z}(p_1)\cdots\mathcal{Z}(p_4)\exp\left(i\sum_{j=1}^{4}\sum_{\mu=1}^{D} p_j^\mu X^\mu(z_j)\right),\end{aligned} \tag{162}$$

并使用显式的逐神经元测度

$$[d\mu_X] = \prod_{i=1}^{N}\left[\frac{d^2W_i}{\mathrm{Vol}(B_\Lambda^2 \setminus B_\epsilon^2)}\frac{dc_i}{2\pi}\prod_{\mu=1}^{D}\frac{da_i^\mu}{\sqrt{2\pi\sigma_a^2}}e^{-(a_i^\mu)^2/2\sigma_a^2}\right]. \tag{163}$$

这里没有路径积分；强调一个关键点，也没有 Monte Carlo：计算是解析的。对输出权重 a_i^μ 的高斯积分是精确的；余下的 W, c 积分对独立同分布的神经元分解为 $[\Phi_N]^N \to \exp(N\log\Phi_N)$，在大 N 极限下指数化为单个神经元的期望。计算后，交叉项恰好组成 Koba–Nielsen 因子

$$\prod_{r<s}|z_r - z_s|^{\alpha' p_r\cdot p_s}, \tag{164}$$

而自收缩（我们从未做正规序）被吸收到重整化 $\mathcal{Z}(p)$ 中。零模高斯分布贡献 $e^{-\sigma_{\rm eff}^2(\sum_r p_r)^2/2}$，它在 $\sigma_{\rm eff}\to\infty$ 时变为 $\delta^D(\sum_r p_r)$：在零模的反紧化极限下，动量守恒由网络密度的平移不变性涌现。结果是论文的最终表达式：标准 Virasoro–Shapiro 振幅，现在作为网络参数空间中的关联函数得到：

$$\boxed{\mathcal{A}^{(4)}=\frac{g_s^2\delta^D(\sum_r p_r)}{\mathrm{Vol}(SL(2,\mathbb{C}))}\int\left(\prod_{\alpha=1}^{4}d^2z_\alpha\right)\prod_{r<s}|z_r-z_s|^{\alpha' p_r\cdot p_s}} \tag{165}$$

它具有交叉对称性、Regge 行为及著名的柔和紫外行为。

对于开弦，将世界面放在上半平面上，并在架构层面通过镜像法实施 Neumann 条件：

$$X_N^\mu(z,\bar z)=\frac{1}{\sqrt{2}}\left[X^\mu(z,\bar z)+X^\mu(\bar z,z)\right], \tag{166}$$

它在 $z\leftrightarrow\bar z$ 下对称，即 $X_N^\mu(z,\bar z)=X_N^\mu(\bar z,z)$。求导即得边界 $z=\bar z$ 上 $\partial X_N^\mu=\bar\partial X_N^\mu$，这就是 Neumann 条件 $(\partial-\bar\partial)X_N^\mu|_{z=\bar z}=0$。镜像项同时使边界传播子加倍。沿类似步骤可以计算 Veneziano 振幅。

这一构造对架构也具有稳健性：任何具有 $1/p^2$ 谱的神经元所组成的 $X^\mu=N^{-1/2}\sum_i a_i^\mu\varphi_i(z)$ 都给出相同的 GP，其中 σ_a 始终扮演 α' 的角色。给出同一 GP 极限的不同架构在有限 N 时可以不同；此时 $1/N$ 的非高斯性会修正振幅。

3.2.4 拓扑缺陷与 BKT 相变

到目前为止，我们构造的一切都使用连续参数。一个自然的离散问题是：拓扑缺陷怎么办？高斯随机特征场是光滑、单值、实值的对象。如果目标空间是紧致的（$\phi\sim\phi+2\pi r$），那么无论如何巧妙地塑造频谱，绕转模和涡旋都不在该系综中。这与路径积分类似：拓扑扇区通过场空间和测度的选择进入，而非通过高斯涨落。文献 [69] 的解决方法相应地具有结构性：扩大潜在空间，加入标记拓扑量子数的离散参数 Q：

$$\langle\mathcal{O}\rangle=\sum_{Q}\int d\theta\,P(\theta,Q)\,\mathcal{O}[\phi_{\theta,Q}], \tag{167}$$

由此得到机制：拓扑扇区求和就是对网络系综的离散潜变量求和。离散潜变量在机器学习中十分常见，例如大语言模型中使用的高斯混合模型或混合专家模型。

一个代表性应用是著名的拓扑相变：二维紧致玻色子 / XY 模型由涡旋解缚驱动的 BKT（Berezinskii–Kosterlitz–Thouless）相变。具体而言，模型的周期场满足 $\theta(x)\sim\theta(x)+2\pi$，作用量为

$$S[\theta]=\frac{K_0}{2}\int d^2x\,(\nabla\theta)^2,\qquad K_0=\frac{\rho_{s,0}}{T}, \tag{168}$$

其中 T 是温度，$\rho_{s,0}$ 是裸自旋刚度，K_0 是控制代数衰减的无量纲刚度（$\eta=1/(2\pi K_0)$）。紧致性允许非零绕转的构型，$\oint_\gamma\nabla\theta\cdot d\boldsymbol{\ell}=2\pi m$，其中 $m\in\mathbb{Z}$（即涡旋）；光滑高斯场无法到达这些构型，它们正是上面的离散扇区 Q。将架构拆分为

$$\theta(x)=b\,\theta_{\rm sw}(x)+\theta_v(x), \tag{169}$$

其中 θ_{sw} 是 XY 自旋角拓扑平凡的光滑部分，θ_v 是奇异的绕转部分，b 与温度有关。

我们将理论放在 $L \times L$ 环面上，并取随机 Fourier 特征作为自旋波：

$$\theta_{\mathrm{sw}}(x) = \frac{A}{\sqrt{N}} \sum_{j=1}^{N} \cos(k_j \cdot x + \gamma_j), \tag{170}$$

其中 $k_j = 2\pi n_j / L$，n_j 按与 $1/|n_j|^2$ 成正比的分布抽样。

涡旋构成离散扇区，其位置和荷记作 $\{(x_a, m_a)\}$，$m_a = \pm 1$，总涡旋数为零，即 $\sum_a m_a = 0$；它们通过以下奇异调和函数进入架构：

$$\theta_v(x) = \sum_{a=1}^{N_v} m_a \arg(x - x_a), \tag{171}$$

离散扇区的密度是中性 Coulomb 气体：

$$P_{\mathrm{vort}} \propto y^{N_v} \exp\left[2\pi K_0 \sum_{a<b} m_a m_b \log(r_{ab} + a_c) \right], \tag{172}$$

其中 y 是涡旋逸度（$y \sim e^{-\beta E_c}$，即涡旋核能的 Boltzmann 权重），a_c 为核正则化参数，K_0 是与 b 相关的刚度。两个扇区统计独立。每个扇区都可以数值采样：自旋波可简单地精确采样，涡旋则使用马尔可夫链（移动一个涡旋、插入或删除一个中性对）。

在这个 NN-FT 中，我们能够计算哪些 BKT 现象？当 $N \to \infty$ 时，可以直接在参数空间中计算自旋波扇区的自旋–自旋关联函数，得到

$$\langle e^{ib\theta_{\mathrm{sw}}(x)} e^{-ib\theta_{\mathrm{sw}}(0)} \rangle \sim |x|^{-\eta}, \qquad \eta = b^2. \tag{173}$$

BKT 对应关系用耦合常数确定温度和刚度；普适临界条件 $\eta_c = 1/4$ 给出相变位置（取单位 $\rho_{s,0} = 1$）：

$$K_0 = \frac{1}{2\pi b^2}, \quad T = 2\pi b^2, \quad \eta_c = \frac{1}{4} \quad \Longrightarrow \quad \boxed{b_c = \frac{1}{2}, \quad T_c = \frac{\pi}{2}}. \tag{174}$$

数值计算接着检验了完整的 BKT 现象：

- T_c **以下**：沿临界线，拟合得到的 η 与 b^2 的差异小于百分之一，并在 b_c 处达到普适值 $\eta = 1/4$（表 1）。
- **自旋波本身永不发生相变**：没有涡旋时，幂律两点函数对所有 b 持续存在，没有相变。
- T_c **以上**：完整两点函数

  $$G_2(r) = \langle e^{i\theta(x)} e^{-i\theta(0)} \rangle \propto e^{-r/\xi} \tag{175}$$

  呈指数衰减，而关联长度呈现 BKT 相变的本性奇异性：

  $$\xi(b) \sim \exp\left(\frac{c}{\sqrt{b^2 - b_c^2}} \right). \tag{176}$$

- **涡旋增殖**：测得的涡旋密度在 b_c 以上急剧增加（图 4）；随温度变化的实空间涡旋分布图见文献 [69]。

- **普适刚度跃变**：从完整场的小动量模的频谱中提取的重整化刚度 Υ_R（螺旋模量），在相变以下跟随 K_0，在相变以上急剧下降，并在相变处穿过 Nelson–Kosterlitz 线

$$\Upsilon_R(T_c^-) = \frac{2}{\pi} T_c, \tag{177}$$

这就是普适跃变。

b	$\eta_{\text{exp}} = b^2$	η_{fit}
0.050	0.00250	0.00252
0.089	0.00791	0.00796
0.158	0.02500	0.02517
0.281	0.07906	0.07963
0.500	0.25000	0.25204

表 1: T_c 以下的幂律指数：沿临界线，拟合指数 η_{fit} 与解析预言 $\eta_{\text{exp}} = b^2$ 的差异小于 1%。引自文献 [69]。

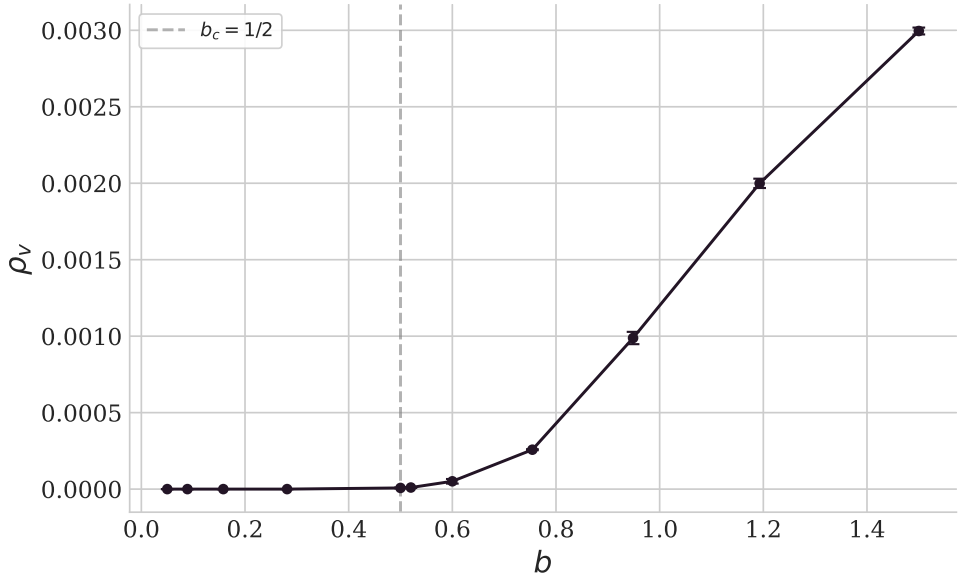


图 4: 涡旋密度 ρ_v 随耦合 b 的变化（虚线标记 $b_c = 1/2$）：相变以下与零相容，相变以上涡旋–反涡旋对解缚，密度急剧上升。引自文献 [69]。

这些是 BKT 相变的主要现象，在包含涡旋的 NN-FT 中得到了明确实现。

3.2.5 反常与 Ward 恒等式

最后一个结果对 NN-FT 至关重要，它回答了从第一天起就萦绕的问题：*在 NN-FT 中如何理解对称性、反常与守恒律？*在路径积分中，Ward 恒等式与反常来自变量替换：用对称变换作用于场，考察积分及其测度是否不变，若不变则读出守恒律；若测度不变性被破坏则得到反常。

文献 [60] 的结果是：NN-FT 自身有一个对参数的积分；将同样的变量替换逻辑应用于此，会产生类似的 Ward 恒等式和反常体系（Schwinger–Dyson，简称 SD，方程是更一般的情况，其中变换不一定是对称性）。该形式体系甚至可用于有限宽度。

主恒等式。 设 $p(\theta) > 0$ 为参数密度，定义**得分函数**

$$s_a(\theta) = \partial_a \log p(\theta), \tag{178}$$

它是现代生成建模的核心对象（文献 [73, 74] 的基于得分函数的生成模型学习的正是这一对象，它们建立在文献 [75] 的扩散框架上），这里则将它用于场论。

推导只需一行。对于任意光滑可观测量 $\mathcal{O}(\theta)$，除去边界通量后，参数空间上全导数的积分为零；用乘积法则展开 $\partial_a(p\mathcal{O}) = p(s_a\mathcal{O} + \partial_a\mathcal{O})$，对每个参数得到一个恒等式：

$$\langle \partial_a \mathcal{O} \rangle = -\langle s_a(\theta)\mathcal{O} \rangle, \tag{179}$$

这里舍弃了边界项。该结果精确成立，不需要假设连续极限、局域性或高斯性。与参数空间中任意光滑向量场 $\xi = \xi^a\partial_a$ 缩并（将 $\mathcal{O}$ 替换为 $\xi^a\mathcal{O}$，再次应用乘积法则，并对 a 求和），得到主恒等式：

$$\left\langle \sum_a \xi^a \partial_a \mathcal{O} \right\rangle = -\langle B(\theta)\mathcal{O} \rangle + (\text{边界项}), \tag{180}$$

其中

$$B(\theta) = \underbrace{\sum_a \xi^a s_a}_{\text{得分}} + \underbrace{\sum_a \partial_a \xi^a}_{\text{Jacobian}} \tag{181}$$

是流 ξ 的**破缺函数**。这里没有假设对称性：每个流都有一个破缺函数。参数流诱导场变分 $\delta_\xi\phi(x) = \sum_a \xi^a \partial_a \phi(x)$；取 $\mathcal{O}$ 为场的乘积，就把式 (180) 变成 n 点 SD 方程，其中得分函数插入扮演场空间中运动方程插入的角色。

Ward 恒等式与守恒律。 参数涨落使生成泛函发生如下变化：

$$\begin{aligned} \delta_\xi Z[J] &= \int d\theta\, p(\theta) \left(\int d^d x\, J(x) \delta_\xi \phi(x) \right) e^{\int J\phi} \\ &= -\left\langle B(\theta) e^{\int d^d x\, J\phi} \right\rangle Z[0] + (\text{边界项}), \end{aligned} \tag{182}$$

第二个等式是对 $\mathcal{O} = e^{\int J\phi}$ 使用主恒等式 (180)。如果该流是系综的对称性，那么

$$\delta_\xi Z[J] = 0, \tag{183}$$

且式 (180) 成为 Ward 恒等式。未破缺对称性的刻画很简洁：由于 $pB = \sum_a \partial_a(\xi^a p)$，所以

$$B = 0 \quad \Longleftrightarrow \quad \partial_a j^a = 0, \qquad j^a = \xi^a p,$$

其中 j^a 是参数空间中的守恒流。这个流不是时空中的局域流，而是 $\mathbb{R}^{|\theta|}$ 上无散度的向量场。

当理论确有局域拉格朗日描述时，可以通过推前恢复熟悉的时空流：在映射到固定场构型的参数纤维上对 $B(\theta)$ 取平均，

$$B_{\text{eff}}[\phi] = \frac{\int d\theta\, p(\theta) B(\theta) \delta[\phi - \phi_\theta]}{\int d\theta\, p(\theta) \delta[\phi - \phi_\theta]}, \tag{184}$$

局域性再将 B_{eff} 转化为 $\int d^d x\, \partial_\mu j^\mu_{\text{eff}}$。下列链条

$$j^a \xrightarrow{\text{散度}} pB(\theta) \xrightarrow{\text{纤维平均}} B_{\text{eff}}[\phi] \xrightarrow{\text{局域性}} \partial_\mu j^\mu_{\text{eff}}(x) \tag{185}$$

中的前两个箭头对任意宽度和架构成立；只有最后一个需要局域性。因此该形式体系足够丰富，甚至能处理无法写出 $j^\mu(x)$ 的非局域 NN-FT。

式 (181) 的分解也因与路径积分的类比而熟悉。当密度沿流不变时，得分项消失（显式破缺位于这一项）；Jacobian 项则与密度无关。它衡量平直测度 $d\theta$ 未能保持不变的程度，是 Fujikawa 反常的有限维对应物。

我们来做一个机器学习中的合理性检验。输入只通过第一隐藏层的预激活进入网络：

$$z_m(x) = \sum_j W^1_{mj} x_j + b^1_m, \tag{186}$$

因此考察输入旋转 $x \mapsto (I + \epsilon\omega)x$ 下系综是否不变，其中 ω 反对称。此旋转可由第一层权重上的补偿流 $\xi^{W^1_{mj}} = \sum_k W^1_{mk}\omega_{kj}$ 抵消（其他所有 $\xi^a = 0$），使每个 $z_m(x)$ 以及每个输出都不变；我们计算它的破缺函数。由反对称性，Jacobian 项立即消失：$\sum_a \partial_a \xi^a = n_1 \operatorname{tr}\omega = 0$。对于高斯独立同分布密度，其得分函数为 $s_{W^1_{mj}} = -W^1_{mj}/\sigma^2$，得分项为

$$B = \sum_{m,j,k} W^1_{mk}\omega_{kj} s_{W^1_{mj}} = -\frac{1}{\sigma^2}\sum_m \sum_{j,k} W^1_{mj} W^1_{mk}\omega_{kj} = 0, \tag{187}$$

因为对称矩阵 $\sum_m W^1_{mj}W^1_{mk}$ 与反对称的 ω_{kj} 缩并。两项都消失：高斯初始化严格具有旋转不变性，主恒等式退化为未破缺的旋转 Ward 恒等式。（这里没有什么依赖于高斯分布的特殊性；任何只通过 Gram 矩阵 $G_{mn} = \sum_j W^1_{mj}W^1_{nj}$ 依赖权重的密度都可达到同样效果。）

将同样工具用于注意力机制的查询 / 键旋转 $W_Q \to RW_Q$、$W_K \to RW_K$，得到的是规范冗余而非物理对称性，从而给出这种冗余应有的平凡 Ward 恒等式；细节留给文献 [60]。

无质量四维 ϕ^4 的尺度反常也以类似方式从此形式体系中出现，单圈 beta 函数从参数空间 Ward 恒等式中得到：

$$\beta(\lambda) = \frac{3\lambda^2}{16\pi^2} + O(\lambda^3). \tag{188}$$

关键在于，β 函数的出现源自参数空间的高斯分部积分：它把破缺函数的得分插入转化为连通四点函数，并通过通常的单圈图产生 β 函数。

Weyl 反常与临界维数。 让我们计算玻色弦的临界维数。我们在圆球面 S^2 上工作：这是最简单的闭合（亏格为零）世界面，其 Laplace 算符谱是一列整齐的球谐函数。在 $L \to \infty$ 时，自由玻色子是一个谐波随机特征场：

$$X^\mu(\hat n) = \sum_{\ell=0}^{L}\sum_{m=-\ell}^{\ell} a^\mu_{\ell m} Y_{\ell m}(\hat n), \qquad \sigma^2_\ell = \frac{2\pi\alpha'}{\ell(\ell+1)}, \tag{189}$$

而 bc 鬼场中，全纯部分 $b \equiv b_{zz}$（自旋权重 $+2$）与 $c \equiv c^z$（自旋权重 -1）按自旋加权球谐函数 ${}_sY_{\ell m}$ [76, 77] 展开；这些球谐函数仅在 $\ell \geq |s|$ 时存在：

$$b(\hat n) = \sum_{\ell=2}^{L}\sum_{m=-\ell}^{\ell} \beta_{\ell m}\, {}_{-2}Y^*_{\ell m}(\hat n), \qquad c(\hat n) = \sum_{\ell=1}^{L}\sum_{m=-\ell}^{\ell} \chi_{\ell m}\, {}_{-1}Y_{\ell m}(\hat n), \tag{190}$$

对于配对的模（$\ell \geq 2$），采用 Grassmann 对的密度

$$p_{bc} \propto \exp\Big(\frac{\mu_\ell}{4\pi}\beta_{\ell m}\chi_{\ell m}\Big), \qquad \mu_\ell = \sqrt{(\ell-1)(\ell+2)} \quad (\ell \geq 2). \tag{191}$$

约束 $\ell \geq |s|$ 使 b 的求和从 $\ell = 2$ 开始，c 的求和从 $\ell = 1$ 开始，因此三个未配对的 $\ell = 1$ 鬼模就是共形 Killing 向量，并由通常的 $c\bar{c}$ 修饰饱和。反全纯的 $\bar{b}, \bar{c}$ 是独立副本（自旋权重 $-2, +1$），这就是下面鬼场 Jacobian 含有因子二的原因。

常数 Weyl 缩放 $g \to e^{2\epsilon}g$ 会缩放 Laplace 算符谱，因此将此 NN-FT 映射为不同背景上的另一个 NN-FT；将变换吸收到参数中，得到线性流：

$$\xi^{a^\mu_{\ell m}} = -a^\mu_{\ell m}, \qquad \xi^{\beta_{\ell m}} = +\beta_{\ell m}, \qquad \xi^{\chi_{\ell m}} = -2\chi_{\ell m}. \tag{192}$$

在破缺函数中，得分项逐扇区与谱的 Weyl 位移抵消——原本可能出现的显式破缺自行消去——只剩下 Jacobian。直接计算表明，Jacobian 完全由模计数给出：

$$B^{(X)}_{\mathrm{Jac}} = -D\left[\sum_{\ell=1}^{L}(2\ell+1)+1\right], \qquad B^{(bc)}_{\mathrm{Jac}} = 2\sum_{\ell=2}^{L}(2\ell+1)+12. \tag{193}$$

当 $L \to \infty$ 时，计数发散；用 zeta 函数正则化，$\zeta_X(0) = -2/3$，$\zeta_{bc}(0) = -5/3$，总结果为

$$B^{\mathrm{reg}}_{\mathrm{anom}} = -D[\zeta_X(0)+1] + 2\zeta_{bc}(0) + 12 = -\frac{D}{3} - \frac{10}{3} + 12 = -\frac{1}{3}(D-26), \tag{194}$$

要求系综具有 Weyl 不变性便得到临界维数 $D = 26$，它来自网络模的计数。

通常的推导通过正规序常数、Polyakov 测度，或 $c_{\mathrm{matter}} + c_{\mathrm{ghost}} = 0$ 得到 26。这里它来自玻色和 Grassmann 参数测度对参数空间中某个流的响应之差，经正则化后的失配。

4 第三天：人工智能在弦论中的应用

第一天和第二天属于理论，重点是理解神经网络的基础及其与场论的关系。今天我们转向实践。我希望使大家掌握弦论中使用的一些主要人工智能技术：学习足以读懂论文的机器学习知识，并了解每种技术的应用。

我有意从一个现代主题——智能体推理模型——开始，因为它改变了其他技术实施的难易程度。我希望大家不仅听完这些应用讲座，还能发现它们对自己的研究有用。智能体能够为应用其他技术扫清障碍。

机器学习技术已在弦论中应用了近十年，始于文献 [78, 79, 80, 81]（综述见 [82, 83, 84]）。我们关注的技术包括监督学习、强化学习、物理信息网络和猜想生成。该领域的年度会议 *String Data* 在 2026 年举办了第十届。与 *Strings* 一样，其物理范围远比弦论宽广，还扩展到场论乃至纯数学。以下按学习类型列出的文献样本远非完整：[2]

弦论数据上的监督回归与分类包括 CICY 和 Kreuzer–Skarke 数据集、线丛上同调、弦标准模型，以及全息、环面簇体积和 BPS 谱等可观测量 [85, 86, 87, 88, 89, 90, 91, 92]。通量真空和异质背景上的强化学习与遗传搜索见 [93, 94, 95, 96, 97, 98, 99, 100, 101, 102, 103]。生成模型见 [104, 105, 106]。物理信息和变分求解器例如用于 Ricci 平坦 Calabi–Yau 度规 [107, 108, 109, 110, 111, 112, 113]。而在低维拓扑中，也有学习纽结不变量并产生严格结果的网络 [114, 115, 116, 117, 84, 118]。

4.1 万事皆可用智能体

在实践中，机器学习用于弦论的研究有大量时间花在基础工作上：构建数据集、把数据整理成张量、编写环境、调整超参数、调试、重新生成图等。今天讲座中许多后续技术以往都要先经历数周的这些工作。然而，**关键点**是：这些基础工作现在可以交出去做。智能体显著降低了尝试新事物的成本，机器学习用于物理的想法如今可以快速制作原型，而两年前还根本无法如此。

智能体究竟是什么？这个词可以有多种含义，但我们这里说的是能够采取行动的机器学习算法。后面我们将讨论由强化学习算法实现的传统概念；但近期进展的核心是智能体式推理模型，例如 [3, 4]：它们是能够在智能体循环中借助工具进行推理、规划和作用于环境的大语言模型。

这种循环有多种形式，图 5 给出一个典型例子：智能体是置于环境中的推理模型。模型接收上下文（任务、迄今的对话和观测），进行思考，然后回答或采取行动：编写并执行代码、搜索文献、调用计算机代数系统、读取文件、派出子智能体处理子任务。环境返回观测（程序输出、错误信息、论文摘要），将其附加到上下文中；循环继续，直到模型判断任务完成并输出推导、代码、图或草稿等成果。这类循环支撑着越来越多的智能体式科学人工智能系统，例如 [119, 120, 121, 122]。

截至 *2026* 年 *7* 月，这能带来什么？具体用例已包括：附带引用的文献侦察，然后由你验证引用；在一个下午复现论文的数值基线；为本讲义中每一种技术生成机器学习的样板代码，而你把时间花在更需要物理学家关注的部分：物理计算及其验证方法。第二天的结果是一个案例：其中几篇论文在研究流程中使用了人工智能辅助，但正确性由人负责。我的研究小组目前的诚实

[2] 如果我遗漏了你的论文，欢迎来信并附上 BibTeX。

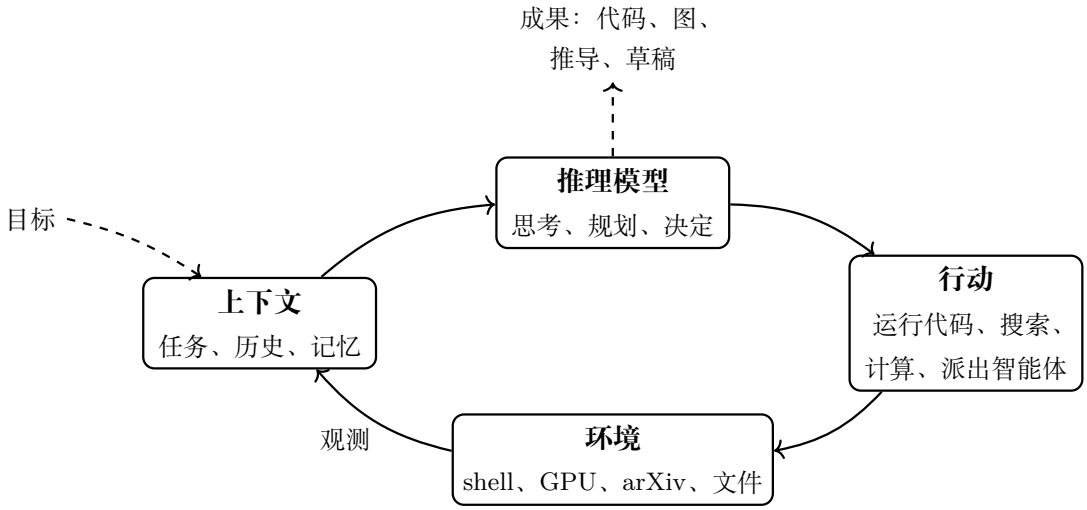


图 5: 智能体循环。推理模型反复思考，通过工具作用于环境，并将所得观测纳入上下文，直至产生一项成果。编排模式（子智能体、批评者、验证循环等）由该循环的不同副本构成。

估计是，机器学习用于弦论项目的实施门槛降低了一个数量级；真正理解这一点的学生将非常高效。

当然，我们必须讨论**重要警示**：

- **看似合理 $\neq$ 正确**。一个令人信服的错误推导比没有推导更糟。像对待合作者一样对待智能体输出：积极对待，但仍需保持批判眼光。无论是代码还是计算，都要检查每一步的来源。
- **验证结果**。要求单元测试、极限情形、量纲分析以及闭式交叉检查（例如第二天的 DOZZ 对比）。能写代码的智能体也能写测试，但要检查测试：奖励投机是真实存在的问题，例如 [123, 124]。
- **虚构的学术内容**。引用、归属及“众所周知的结果”始终必须核查。有一些好的工作流程，例如要求直接从 INSPIRE 获取带可点击链接的 BibTeX。
- **你才是物理学家**。智能体降低了做物理的成本，但它们并不总有良好的判断，也从不对所声称的结果承担责任。

随着智能体技术在未来几年继续发展，这些和其他注意事项都值得牢记。

这一流程的一个具体实现，也是我和同事们构建并使用的工具，是 **Get Physics Done**（GPD） [122]，它是 Physical Superintelligence 开发的开源智能体式人工智能物理学家。GPD 将图 5 的循环封装成一个物理研究流程：界定问题及其假设、制定分阶段计划、派出专业子智能体开展推导和数值工作，并运行验证阶段，依据自然界施加的约束（例如量纲、极限情形、对称性）检查结果，同时保持各阶段记号一致。它将上面强调的纪律内置于流程，包括用于本讲义的 INSPIRE 来源引用检查。它可以作为命令安装在 Claude Code 或 Codex 等现有编码运行环境中，也在作为独立应用进行 beta 测试。

在这样的框架下，智能体为经典技术增效；现在让我们学习其中一些经典技术。

4.2 物理信息神经网络与 Calabi–Yau 度规

4.2.1 物理信息神经网络

假设我们希望求解偏微分方程

$$\mathcal{D}[u](x) = 0 \quad \text{在}\Omega\text{ 上}, \qquad \mathcal{B}[u](x) = 0 \quad \text{在}\partial\Omega\text{ 上}, \tag{195}$$

其中 $\mathcal{D}$ 是（一般为非线性的）微分算符，$\mathcal{B}$ 编码边界或其他条件。**物理信息神经网络**（PINN）策略 [125, 126] 简单得出人意料：令网络 u_θ 对解建模，调整 θ 以满足所需的物理规律。具体算法如下：

1. **架构**。选择具有足够表达能力来表示该解的网络架构 u_θ。
2. **采样**。取点 $\{x_i\} \subset \Omega$ 和 $\{x_j\} \subset \partial\Omega$。
3. **回归**。取损失为

$$\mathcal{L}[\theta] = \frac{1}{n}\sum_{i=1}^{n} |\mathcal{D}[u_\theta](x_i)|^2 + \lambda_{\mathcal{B}} \frac{1}{m}\sum_{j=1}^{m} |\mathcal{B}[u_\theta](x_j)|^2 + \cdots, \tag{196}$$

优化参数以最小化损失，并（近似）求解方程。

这里的省略号可包括归一化约束或你希望解满足的任何其他可微要求。$\mathcal{D}[u_\theta]$ 中的导数可由自动微分直接得到，即支持反向传播的同一套机制。PINN 的优点包括表达能力和易于纳入各种约束。常见弱点是损失项之间的平衡，以及优化器心满意足地落入错误局部极小值却不发出警告的失败模式。对后者的部分回答是*经验证的数值计算*：将网络的近似解与严格证明配对，证明其附近存在真正的解；近期关于偏微分方程的计算机辅助工作 [127] 与 Euler 方程不稳定奇点的发现 [128] 就是例子。凝聚态和量子化学中的一个平行研究方向使用神经网络变分试探态寻找量子多体基态 [129, 130, 131, 132]。

PINN 的最后一个重要概念是*代理损失*：对于难以直接优化的目标，用一个易于处理且可微的替代量来代替。我们将在 Calabi–Yau 度规中看到一个明确的例子。

4.2.2 Calabi–Yau 度规

弦论为我们提供了一个很好的 PINN 问题。考虑你喜欢的弦论在一个 Calabi–Yau 三重流形上的紧化。一个重要结果是 Yau 定理 [133]：

定理 4.1 (Yau)**.** *对于满足 $c_1(X) = 0$ 的紧 Kähler 流形 X，其每个 Kähler 类中都有唯一的 Ricci 平坦 Kähler 度规。*

这是一个真正非凡的结果。我们愿意将其表述为**奇迹一：从拓扑到几何**。做一个简单的拓扑检查，便能保证 Ricci 平坦度规的存在。

事实上，这个检查很容易，以至于有许多构造 Calabi–Yau 三重流形的算法，从而得到**指数级庞大的几何空间数量**。仅 Kreuzer–Skarke 分类就给出 473,800,776 个自反四维多胞体 [134]，其 Calabi–Yau 超曲面的数量上界约为 10^{428} [135]，估计可分为约 10^{400} 个微分同胚类 [136]；在 F 理论方面，一种构造算法可达到包含 $\frac{4}{3} \times 2.96 \times 10^{755}$ 个几何空间的系综 [137, 138]，它们一

般带有大量轴子 [139, 140]。尽管如此，我们面对一个**令人不安的事实**：对于具有完整 $SU(3)$ 和乐群的紧三重流形，我们不知道任何 Calabi–Yau 度规。当然，我们知道 T^6 上的 CY 度规，但不知道完整 $SU(3)$ 和乐群情形下的度规；后者是 $\mathcal{N}=1$ 紧化中感兴趣的情况。

令人惊讶的是，我们在不知道空间上基本对象的情况下，竟然能在 Calabi–Yau 背景中做这么多弦几何研究！我们是如何做到的？在进入机器学习问题和技术之前，先回答这个问题。不错，我们知道存在性，这很重要。我们也可以计算许多拓扑量，例如交数、Hodge 数、向量丛上同调等，它们编码电荷、规范群、粒子世代数等离散物理量。然而，尽管这些发生在弦几何中，相关计算实际上是弦拓扑的计算。

当然，我们也会计算 CY 紧化中的连续量，例如全纯规范耦合、BPS 粒子质量、BPS 膜张力等。这些无疑是几何计算，例如与 CY 及其子流形体积有关。但这又提出一个问题：没有度规，怎么计算体积？这归功于 Harvey 和 Lawson 的开创性工作 [141]。

奇迹二：标定几何。我们通过积分标定形式来计算被标定子流形的体积；例如全纯曲线 C 的体积为

$$\mathrm{Vol}(C)=\int_C J, \tag{197}$$

其中 J 是 Kähler 形式。这样的被标定子流形在其同调类中使体积最小。为何可以不依赖度规来计算体积？数学上的回答是标定，但相关的**物理原因是 BPS 性质**。BPS 对象受超对称保护，可通过将膜缠绕在被标定子流形上得到。CY3 中的除子、特殊 Lagrange 子流形和全纯曲线分别是被标定的四维圈、三维圈和二维圈，其相应标定形式为 $J\wedge J$、$\mathrm{Re}(\Omega)$ 和 J。

一个对照例子能清楚展示 BPS 性质与标定几何之间的联系：虽然 G_2 和乐流形有被标定的三维圈和四维圈，却没有被标定的二维圈。在 $\mathcal{N}=1$ 的 M 理论 G_2 紧化中，通过将 M5 膜缠绕在被标定三维圈和四维圈上会得到 BPS 畴壁和弦，但缠绕的 M2 膜不会产生 BPS 粒子。G_2 和乐流形中缺少被标定二维圈就是这一现象的几何原因。关于 G_2 情形的深入讨论，见文献 [142]。

由于我们没有 CY 度规的表达式，我们问：神经网络能否逼近 CY 度规？正如刚才所回顾的，这在物理上很重要。关于数值 CY 度规已有大量文献：代数试探形式上的 Donaldson 平衡度规算法 [143, 144]、Headrick–Wiseman 和 Headrick–Nassar 的格点与能量泛函方法 [145, 146]，以及 Donaldson 与机器学习结合的方法 [107]。2020 年，神经网络成为一种新的试探形式 [109, 108, 110]，也是当前的先进方法。仅靠拓扑与标定几何无法得到的是确实依赖度规的量，例如物理的（正则归一化的）Yukawa 耦合、物质场的 Kähler 度规和 Kaluza–Klein 模式。这正是数值 Calabi–Yau 度规使我们能够获得的：一旦网络逼近了 Ricci 平坦度规，便可计算归一化 Yukawa 耦合 [109, 147, 148, 149]、丛斜率与近似 Hermitian–Yang–Mills 联络 [112, 107]、Kaluza–Klein 模式 [150]，以及未来几年可能出现的更多可观测量。

在介绍能够产生更强结果的更巧妙机器学习方法之前，为教学起见先做最直接的事。最字面的 PINN 直接输出度规分量：用神经网络表示度规 $g^\theta_{\mu\bar\nu}(x)$，优化 θ 以实现 $R_{\mu\bar\nu}=0$。要使 $R_{\mu\bar\nu}\to 0$，需要计算未受约束的 g^θ 的 Ricci 张量，它相对度规是二阶导数表达式。最直接的损失是 Ricci 分量的均方误差：

$$\mathcal{L}_{\mathrm{Ricci}}[\theta]=\frac{1}{n}\sum_{i=1}^{n}\sum_{\mu,\bar\nu}|R_{\mu\bar\nu}(x_i)|^2. \tag{198}$$

但这有两个问题。第一，Ricci 张量比度规高两阶导数，因此每次计算时都要通过带噪声的二阶导数链进行反向传播。第二，式 (198) 既不能保证 g_θ 是 Kähler，也不能固定其 Kähler 类：零

损失集具有简并性（包括 Kähler 模空间和非 Kähler 的 Ricci 平坦形变），而且 Kähler 类可能漂移。

可以利用 Yau 证明中的细节改进这一点。在固定 Kähler 类中，Ricci 平坦性等价于复 Monge–Ampère 方程：

$$J_{\mathrm{CY}} \wedge J_{\mathrm{CY}} \wedge J_{\mathrm{CY}} = \kappa\, \Omega \wedge \bar{\Omega}, \tag{199}$$

这是一个微分形式方程，必须在 Calabi–Yau 上逐点匹配。Kähler 结构也使导数更易处理：度规现在来自单个 **Kähler 势** K，

$$g_{\mu\bar{\nu}} = \partial_\mu \partial_{\bar{\nu}} K \tag{200}$$

（所以 $J = i\partial\bar{\partial}K$），Ricci 形式

$$R_{\mu\bar{\nu}} = -\partial_\mu \partial_{\bar{\nu}} \log \det g \tag{201}$$

相对度规高两阶导数，相对势则高四阶（这就是文献 [112] 默认关闭 Ricci 损失的原因）；而 Monge–Ampère 代理损失直接约束 J_{CY}，少两阶导数。写成

$$J_{\mathrm{CY}} = J_{\mathrm{ref}} + \partial\bar{\partial}\phi \tag{202}$$

便自动纳入 Kähler 性并固定 Kähler 类。前者是因为 $\partial\bar{\partial}\phi$ 自动为 d 闭形式，所以 J 保持为闭 $(1,1)$ 形式；后者是因为 $\partial\bar{\partial}\phi$ 全局恰当（ϕ 是真正的函数），依据 $\partial\bar{\partial}$ 引理有 $[J] = [J_{\mathrm{ref}}]$，它不能漂移。回忆 Kähler 形式和度规是相同数据，$J_{\mu\bar{\nu}} = i g_{\mu\bar{\nu}}$，可从修正后的形式直接读出度规：

$$g_{\mu\bar{\nu}} = (g_{\mathrm{ref}})_{\mu\bar{\nu}} + \partial_\mu \partial_{\bar{\nu}} \phi. \tag{203}$$

给定 J_{ref} 后，可以用神经网络 ϕ_θ 对修正项建模。

Larfors、Lukas、Ruehle 和 Schneider [112] 在程序包 `cymetric` [151] 中正是这样做的：对于完全交（CICY）和 Kreuzer–Skarke Calabi–Yau 空间，可以在模空间中任意位置应用。相关开源程序包还有 `cymyc` [148] 和 `CYJAX` [113]。其**算法**有三个基本组成部分：试探形式、数据采样器和损失函数。

试探形式。 学习相对参考形式的修正；ϕ 模型预测

$$J_{\mathrm{pred}} = J_{\mathrm{ref}} + \partial\bar{\partial}\phi_\theta, \tag{204}$$

其中 J_{ref}（例如拉回的 Fubini–Study 形式）固定 Kähler 类，标量网络 ϕ_θ 在学习中优化。作者也允许矩阵值试探形式，它们不保证 Kähler 性，而是通过损失项恢复这一性质。

数据。 通过与随机直线求交来从 X 中采样点；Shiffman–Zelditch 型定理在此精确给出测度。积分变成加权 Monte Carlo 求和：

$$\int_X \mathrm{dVol}_{\mathrm{CY}}\, f \simeq \frac{1}{N} \sum_i \widetilde{w}_i \det g(p_i) f(p_i), \tag{205}$$

其中 p_i 是采样点，Shiffman–Zelditch 定理精确确定它们的 Fubini–Study 采样测度 $\mathrm{d}A$；因此 $\widetilde{w}_i$ 是将该测度转换为 CY 测度的已知因子 [112]。

损失。 文献 [112] 使用的 `cymetric` 损失将物理规律纳入模型。这个损失是残差的加权和 $\mathcal{L} = \sum_k \alpha_k \mathcal{L}_k$：

$$\mathcal{L}_{\mathrm{MA}} = \left\| 1 - \frac{1}{\kappa} \frac{J_{\mathrm{CY}} \wedge J_{\mathrm{CY}} \wedge J_{\mathrm{CY}}}{\Omega \wedge \bar{\Omega}} \right\|, \tag{206}$$

$$\mathcal{L}_{\mathrm{dJ}} = \sum_{ijk} \big(\|\mathrm{Re}\, c_{ijk}\| + \|\mathrm{Im}\, c_{ijk}\| \big), \quad c_{ijk} = g_{i\bar{j},k} - g_{k\bar{j},i}, \tag{207}$$

$$\mathcal{L}_{\mathrm{trans}} = \frac{1}{d} \sum_{\text{坐标片}} \left\| g^{(\mathcal{V})} - T g^{(\mathcal{U})} T^{\dagger} \right\|, \tag{208}$$

$$\mathcal{L}_{\mathrm{Kclass}} = \frac{1}{h^{1,1}} \sum_{\alpha} \left\| \mu(\mathcal{O}(e_\alpha)) - \int_X J^2 \wedge F_{\mathrm{FS},\alpha} \right\|. \tag{209}$$

Monge–Ampère 残差 (206) 实施式 (199)；对于不自动满足这些性质的试探形式，$\mathcal{L}_{\mathrm{dJ}}$ 和 $\mathcal{L}_{\mathrm{trans}}$ 分别恢复 Kähler 性和坐标片一致性；斜率损失 $\mathcal{L}_{\mathrm{Kclass}}$ 则提供全局约束，把计算得到的线丛斜率 $\mu(L) = \int_X J^2 \wedge c_1(L)$ 与其精确拓扑值匹配，从而固定 Kähler 类。文献 [112] 通过这种训练在五次超曲面、双三次曲面和一个 Kreuzer–Skarke 流形上得到了度规。

4.2.3 与 Ricci 流的关系

训练神经网络使之成为度规，是 θ 空间中的梯度下降；但随着网络学习，它诱导出度规空间中的流。一个自然的问题是：*Ricci 流是否为神经网络度规流？*毕竟，我们讨论过的神经网络技术和 Ricci 流都具有 Ricci 平坦不动点。

第一天提供了回答这个问题的工具 [152]。链式法则把参数空间的梯度下降变成度规的流，即**度规流**：

$$\frac{dg_{ij}(x)}{dt} = -\int_X d\mu(x')\, \Theta_{ijkl}(x,x') \frac{\delta \ell(x')}{\delta g_{kl}(x')}, \tag{210}$$

它由逐点损失 ℓ 的泛函导数驱动，并由**度规神经切线核**支配：

$$\Theta_{ijkl}(x,x') = \partial_{\theta_I} g_{ij}(x)\, \partial_{\theta_I} g_{kl}(x'). \tag{211}$$

一般而言，这个核依赖参数、依赖时间、具有随机性且非局域，因此一般的度规流不是 Ricci 流。Ricci 流是一个特殊情形，通过三个与第一天完全平行的限制得到：

- **无限宽度**。当 $N \to \infty$ 时，核冻结为确定性的、与时间无关的 $\bar{\Theta}$：没有特征学习。
- **局域性**。如果冻结核塌缩成 delta 函数，$\bar{\Theta}_{ijkl}(x,x') = \delta(x-x')\delta_{ik}\delta_{jl}\bar{\Omega}(x)$，则非局域性和指标混合消失，流变为局域的：$dg_{ij}(x)/dt = -\bar{\Omega}(x)\delta\ell(x)/\delta g_{ij}(x)$。
- **Perelman 损失**。选取损失为 Perelman 泛函的负值，$\ell = -\mathcal{F}[\phi, g]/\bar{\Omega}$，其中 $\mathcal{F}[\phi,g] = \int_X (R + |\nabla\phi|^2) e^{-\phi}\, dV$，该流便变成 Perelman 形式的 Ricci 流，即三维 Poincaré 猜想证明背后的流。

因此一般而言，**Ricci 流是无限宽神经网络度规流的一个特殊情形**。图 6 展示了这一点，也解释了为何 CY 度规流反而取得了成功：它们利用了特征学习。



图 6: 神经网络度规流的层级 [152]。一般流是非局域、随机且含时的；无限宽度使核冻结，局域性使核塌缩成 delta 函数，选择 Perelman 泛函作为损失后得到 Ricci 流。

4.3 强化学习与搜索

4.3.1 强化学习基础

弦论中的许多问题都有丰富结构和庞大的构型空间。我们将考虑一个抽象的景观。如何学会搜索庞大景观？这必须依据景观所提供的条件进行：通常是一个巨大的构型空间，其状态由离散和 / 或连续的量定义；还有 “好” 和 “坏” 的概念，以及探索的能力。这正是**强化学习**（RL）[153] 的自然用武之地。

计算机科学中一个简洁概念形式化了这种环境：

定义 4.2 (马尔可夫决策过程（MDP）)**.** *状态 $s \in \mathcal{S}$、行动 $a \in \mathcal{A}$、折扣系数 $\gamma \in [0,1)$，以及由马尔可夫转移核 $P(s'|s,a)$ 和奖励 $r(s,a)$ 给出的动力学。MDP 是五元组 $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$。*

强化学习在 MDP 之上提出一个控制问题：**策略** $\pi_\theta(a|s)$（在这里是神经网络）是以状态为条件的行动分布（可能是确定性的）。我们希望获得高回报

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t \geq 0} \gamma^t r(s_t, a_t) \right], \qquad s_0 \sim \mu_0, \tag{212}$$

其中期望关于策略 π_θ 和 MDP 动力学生成的轨迹 $\tau = (s_0, a_0, s_1, a_1, \ldots)$ 取，s_0 从某个初始分布 μ_0 抽取。强化学习的目标是找到使 $J(\theta)$ 最大化的策略。

价值函数记录从某个状态或状态–行动对出发的预期回报：

$$V^{\pi_\theta}(s) = \mathbb{E}_{\pi_\theta}\left[\sum_{t\geq 0}\gamma^t r(s_t,a_t)\,\middle|\, s_0 = s\right],$$
$$Q^{\pi_\theta}(s,a) = \mathbb{E}_{\pi_\theta}\left[\sum_{t\geq 0}\gamma^t r(s_t,a_t)\,\middle|\, s_0 = s,\ a_0 = a\right], \tag{213}$$

而优势函数

$$A^{\pi_\theta}(s,a) = Q^{\pi_\theta}(s,a) - V^{\pi_\theta}(s) \tag{214}$$

衡量一个行动比策略的平均表现好多少：强化有效的行动，抑制无效的行动。

策略梯度定理使目标可以训练：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}\left[\sum_t \gamma^t \nabla_\theta \log\pi_\theta(a_t|s_t)\, Q^{\pi_\theta}(s_t,a_t)\right]. \tag{215}$$

常用优势函数 A^{π_θ} 替代 Q^{π_θ}（等价于减去依赖状态的基线）。这不会改变期望梯度（减去任何与行动无关的基线 $b(s_t)$ 均不改变期望梯度），通常还会降低方差。这也使强化学习能够针对不可微奖励进行训练，例如黑箱评分器或离散的正确性检查。我们不对奖励求导：通过对数导数技巧，

$$\begin{aligned}\nabla_\theta \mathbb{E}_{\tau\sim p_\theta}[R(\tau)] &= \mathbb{E}_{\tau\sim p_\theta}[R(\tau)\nabla_\theta \log p_\theta(\tau)] \\ &= \mathbb{E}_{\tau\sim p_\theta}\left[R(\tau)\sum_t \nabla_\theta \log\pi_\theta(a_t|s_t)\right],\end{aligned} \tag{216}$$

整个梯度由可微的对数概率 $\log\pi_\theta$ 承载，而回报 $R(\tau)$（或 Q^{π_θ}、优势函数）只作为标量权重进入。因果性（t 时刻之前已获得的奖励不能依赖 a_t）使我们可以把第 t 项中的 $R(\tau)$ 换成从 t 开始的折扣后续奖励，其条件期望为 $\gamma^t Q^{\pi_\theta}(s_t,a_t)$，从而恢复式 (215)。

三类基本方法的区别在于它们对什么进行参数化：

- **基于价值**。学习行动价值函数，通常是最优价值 Q^* 的近似；策略于是是隐式的：采用贪心行动，即取价值最高的行动 $\arg\max_a Q(s,a)$；或采用 ϵ-贪心行动，即以概率 $1-\epsilon$ 采取贪心行动，以概率 ϵ 均匀随机选取行动以保持探索。在深度 Q 学习中，用普通反向传播通过时序差分损失，将 $Q_\phi(s,a)$ 回归到自举目标 $r + \gamma\max_{a'} Q_{\bar\phi}(s',a')$；其中来自目标网络 $\bar\phi$ 的下一状态估计保持固定。例如 Q 学习 / 深度 Q 网络 [154]。

- **基于策略**。对 π_θ 参数化并直接优化策略目标 (215)。最纯粹的情形如 REINFORCE，不需要学习价值函数；实践中，TRPO 等方法虽然仍以策略作为主要学习对象，也经常使用基线或优势估计。梯度通过上述对数导数技巧流过 $\log\pi_\theta$。例如 REINFORCE，以及限制每步 KL 变化的信赖域方法 TRPO [155]。

- **行动者–评论家**。两者都学习：评论家通过时序差分回归估计 V^{π_θ}、Q^{π_θ} 或优势函数；行动者以评论家的估计作为权重，通过策略梯度更新 π_θ。评论家降低梯度方差，但在估计不准时会带来偏差。例如 A3C [156]，它异步更新多个环境副本。

深度强化学习的代表性成果（从像素学习 Atari 游戏 [154]，通过自我对弈学习围棋和国际象棋 [157, 158]）来自上述方法加搜索；第 4.1 节的推理模型是它们最新的后继者：在思维链上进行强化学习，行动是下一个 token，奖励对完整答案评分。这里后训练的主力方法是**组相对策略优化**（GRPO）[4]。对于每个提示，它从旧采样策略中抽取一组回答并分别评分。该组提供自己的基线：输出的优势是其奖励在该提示的组内标准化后的值（减去均值，再除以组标准差），因此高于组平均值的回答被强化，低于平均值的被抑制，无需学习价值函数。随后，回答级优势作为权重作用于该回答中 token 对数概率的更新。策略使用 PPO 风格的目标更新，并包含相对于参考模型的 KL 惩罚。

最后提出关键问题：*强化学习何时胜过盲目搜索？当问题具有可学习的结构时*：奖励塑形为趋向一致性提供梯度，而解集中的规律可由策略内化。这两种现象都会在弦论应用中鲜明呈现。

4.3.2 探索弦真空

在文献 [93] 中，我们让深度强化学习在环面定向翻折上相交 D6 膜构成的 IIA 型紧化景观中自由探索。环境设定如下：状态是一个膜构型；行动是添加或修改膜；奖励根据构型接近弦论一致性（一组耦合的非线性丢番图方程）和类似标准模型的规范扇区的程度评分。具体地，一叠 N_a 张 D6 膜缠绕在特殊 Lagrange 三维圈 $\Pi_a \subset X$ 上（其定向翻折像为 Π_a'），智能体必须引导构型满足定向翻折一致性条件 [159]：

- **RR 蝌蚪消除**，*一个同调方程*：净 D6 膜电荷必须抵消 O6 平面电荷，

$$\sum_a N_a\big([\Pi_a] + [\Pi_a']\big) = 4[\Pi_{O6}] \in H_3(X, \mathbb{Z}). \tag{217}$$

- **K 理论（$\mathbb{Z}_2$）约束**：同调无法看见的挠电荷也必须消失，即不存在全局 Witten 反常；它可由 Sp 探针膜探测。

- **超对称性**：每个 Π_a 都必须是特殊 Lagrange 三维圈，也就是由 $\mathrm{Re}\,\Omega$ 标定：

$$J|_{\Pi_a} = 0, \qquad \mathrm{Im}\,\Omega|_{\Pi_a} = 0, \tag{218}$$

  因此 $\mathrm{Re}\,\Omega$ 在 Π_a 上的限制成为体积形式。单张这样的膜保持 $\mathcal{N} = 1$；要使所有膜堆（以及 O6 平面）保持*共同的* $\mathcal{N} = 1$，它们必须关于相同的 $\mathrm{Re}\,\Omega$、即相同相位被标定。在可分解环面 $T^6 = \prod_{I=1}^3 T_I^2$ 上，一叠膜在每个 T_I^2 上相对 O6 平面以角度 θ_a^I 缠绕，其标定相位是 $\sum_I \theta_a^I$，共同相位条件化为角度和条件：

$$\sum_{I=1}^{3} \theta_a^I = 0 \pmod{2\pi}, \tag{219}$$

  其中 θ_a^I 是第 I 个 T^2 上的缠绕角。

- **类似标准模型的数据**（这是目标，不是一致性要求）：双基本表示 $(N_a, \bar{N}_b)$ 中的手征物质由拓扑交数 $I_{ab} = [\Pi_a] \cdot [\Pi_b]$ 计数；因此类似标准模型的谱（规范群 $\supseteq SU(3) \times SU(2) \times U(1)$，具有三代手征粒子）固定了相关交数 $I_{ab} = \pm 3$。

一个有代表性的奖励塑形形式会惩罚对约束的违反，并奖励达成目标（文献 [93] 中的确切塑形不同，这里只是示意）：

$$R = -\sum_a w_a |\Delta_a| + (\text{类似标准模型时的奖励}), \tag{220}$$

其中 Δ_a 是上述约束的（带符号）违反量，w_a 是权重，因此当构型趋于一致时 R 向零增加。

使用与此环境交互的 A3C 智能体 [156] 探索 IIA 模型；它根据 R 更新策略和价值网络并学习。值得记住的结果是：

- **效率**。训练后，智能体找到一致模型的速率最高达到随机游走者的 $O(200)$ 倍。
- **重新发现人类策略**。在一个任务中，智能体学到的策略重现了人类模型构造中熟悉的策略（所谓用填充膜饱和蝌蚪条件）：它自行找到了我们的技巧。
- **真正的新策略**。在另一个没有已知人类推导策略的任务中，智能体发明了一种策略，达成目标的效率是受人类启发的基线的两倍。

智能体并没有施展魔法；它对丢番图方程解集做统计，并把结构缓存于策略中。但“学会景观某一角落的结构”正是我们想要的能力。**关键点：**给定可学习的结构，强化学习不仅搜索得更快，还能发现新策略。

景观中相关的搜索技术包括遗传算法 [80, 97]。许多工作 [95, 96, 99, 100, 98] 使用强化学习和 / 或遗传算法，有时还比较二者。更广泛的综述见文献 [82]。

4.3.3 学习解开纽结与 Poincaré 猜想

强化学习不仅适用于景观：它还可以在证书意义上严格确立数学与物理对象的性质。我们回顾一个低维拓扑中的例子 [116]。

UNKNOT 问题询问给定纽结是否为平凡结，它可以转化为一个关于语言的问题。一个纽结用**辫词**表示：由 Artin 生成元的有限字母表 $\{\sigma_1^{\pm 1}, \dots, \sigma_{n-1}^{\pm 1}\}$ 构成的字符串。判定 UNKNOT 就成为序列分类；而简化辫子的操作（见下文）构成这些字符串上的重写语法。将其作为语言问题后，便可以使用语言模型：Transformer 架构（Reformer、共享 QK）能够根据辫词以高准确率分类是否为平凡结（有趣的是，准确率随辫长增加），同时在没有提示的情况下学得 Jones 多项式的某种内部对应物，其置信度追踪该多项式的次数。第 4.4 节将再次讨论这一点。

n 股辫子是 *Artin* 生成元 σ_i（第 i 股从第 $i+1$ 股上方交叉）及其逆元 σ_i^{-1} 的乘积；其闭合（将每股的顶端与其自身底端连接）得到一个纽结或链环。最简单的例子是只有一个交叉的两股辫子 $\sigma_1 \in B_2$（图 7）：其闭合是**平凡结**，因为唯一的交叉可以通过 Reidemeister-I 操作消去。难点在于，长得多的辫词闭合后也可能是平凡结，而且短计算无法看出这一点；这正是判定 UNKNOT 困难、以及下文强化学习“通过操作简化”的框架适合此问题的原因。

让我解释强化学习结果。有两族操作连接具有相同闭合的辫词（图 8）：B_n 内部的**辫关系**和联系不同 B_n 的 **Markov 操作**：

$$\begin{aligned} &\text{辫关系：} && \sigma_i\sigma_{i+1}\sigma_i = \sigma_{i+1}\sigma_i\sigma_{i+1}, \quad \sigma_i\sigma_j = \sigma_j\sigma_i \ (|i-j| \geq 2), \\ &\text{自由约消：} && \sigma_i\sigma_i^{-1} = 1, \\ &\text{Markov：} && w \simeq gwg^{-1}, \quad w \simeq w\sigma_n^{\pm 1} \ \ (\text{稳定化 / 去稳定化}), \end{aligned} \tag{221}$$

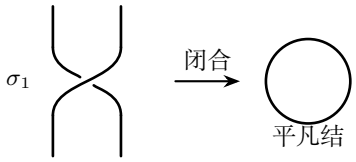


图 7: Artin 生成元 $\sigma_1 \in B_2$：两股辫子有一个交叉。闭合辫子（将每股顶端与其自身底端连接）得到一个单环，即平凡结。

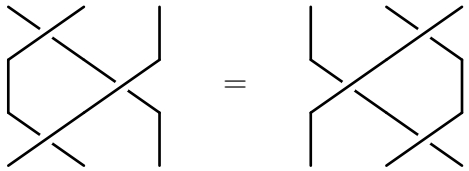


图 8: 辫关系 $\sigma_i\sigma_{i+1}\sigma_i = \sigma_{i+1}\sigma_i\sigma_{i+1}$（这里为三股辫且 $i = 1$），即辫词形式的 Reidemeister-III 操作，也是训练后的智能体最常依赖的操作。其余类型在辫词上以同样的代数方式作用：远距离交换 $\sigma_i\sigma_j = \sigma_j\sigma_i$、自由约消 $\sigma_i\sigma_i^{-1} = 1$（Reidemeister II），以及 Markov 稳定化 / 去稳定化（Reidemeister I）。

其中去稳定化、自由约消和辫关系分别是 Reidemeister 操作 I、II 和 III 在辫词上的对应形式。如果存在一串这样的操作将辫词化为空词，就得到平凡结的证书。将操作选择建模为 MDP，并用 TRPO [155] 训练：智能体学会了简化，在广泛的交叉数范围内持续给出明确的解结序列（人可检查的证书，而不仅是分类），而其他强化学习算法和随机游走者在此范围内失败。分析学得的策略本身也提供信息：智能体对辫关系的依赖超过其中一种 Markov 操作；这是从训练统计中涌现出来的关于解结几何的陈述。这种产生证书的模式——艰难搜索，轻松验证——是纯数学家能够以完全严格的标准接受机器学习结果的范本 [84]。

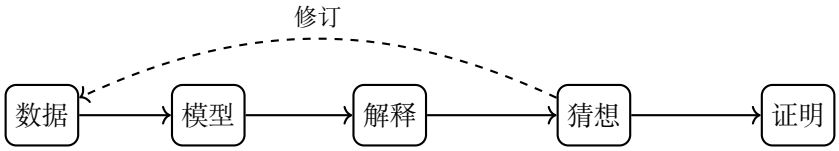
同样的方法还可以用于光滑四维 Poincaré 猜想（SPC4），这是拓扑学中的一个重大开放问题。一种已知的反驳策略涉及满足某些零手术与 slice 性质组合的纽结对。具体地说，如果纽结 (K_1, K_2) 的零手术相同，且其中恰有一个是 slice 纽结，那么 SPC4 为假。在文献 [118] 中，slice 性质的证明交给贝叶斯优化和强化学习；若上述性质得以确立，就构成对 SPC4 的严格反驳。对于一族 3375 个候选 [160]，程序从列表中排除了除两个以外的所有候选：通过证明纽结对要么都不是 slice、要么都是 slice，排除了许多被提出的 SPC4 反例。

4.4 猜想生成与严格性

4.4.1 从预测到理解

监督学习（第一天）给出一个能够预测、但带有误差的函数。我们往往希望得到更多：*能否解释机器学习，以获得定理？*使用模式是**猜想生成** [81]：受训练网络提供候选模式，然后由科学家尝试精确表述并证明。

机器学习可以用这种方式驱动发现循环的提议很早就出现在弦景观背景中。后续弦论例子包括线丛上同调的猜想公式 [88] 和 F 理论物质谱的可解释模型 [161]，随后 DeepMind 在纯数学中给出了引人注目的示范 [117]。工作流程为：



解释阶段根据机器学习算法的细节有不同工具：

- **可解释模型类别**。线性与逻辑回归、决策树和小型森林直接展示权重、划分和特征重要性。在结构化数学数据上，它们往往可与深度网络匹敌；应总是先尝试简单方法。
- **归因**。对于深度网络，基于梯度的显著性按影响大小排列输入特征：网络实际使用了哪些不变量？
- **按设计可解释的架构**。KAN（第一天）学习的一元激活函数可以读出并转换为符号形式 [24]；符号回归则将训练后的网络提炼为公式。
- **程序作为假设**。大语言模型时代的一种变体是搜索代码而非权重 [12, 13]，因此发现的对象按构造即可解释：读程序即可。

4.4.2 猜想生成案例

F 理论系综中的规范群。 在文献 [81] 中，我们对由

$$N = \frac{4}{3} \times 2.96 \times 10^{755} \tag{222}$$

个 F 理论紧化构成的系综进行猜想生成，并让模型保持足够简单以便解释。一个**决策树**从自反多胞体预测弱 Fano 三维环面簇的数量（每个都给出光滑的 F 理论几何）；**线性回归**重新导出了关于规范群秩的一个已知猜想；**逻辑回归**则产生一个关于 E_6 扇区何时出现的新猜想，随后我们证明了它 [84]。

DeepMind 的纽结不变量。 数学家运行了同一循环 [117]：训练网络根据双曲纽结的几何不变量预测其符号数 $\sigma(K)$，用梯度显著性发现只有少数不变量重要，再将其提炼为一个新不变量——从尖点几何读出的自然斜率 $\mathrm{slope}(K)$。网络实际上猜测了 $\mathrm{slope}(K) \approx 2\sigma(K)$，后来被严格化为 [162]

$$\big|2\sigma(K) - \mathrm{slope}(K)\big| \le c\frac{\mathrm{vol}(K)}{\mathrm{inj}(K)^3}, \tag{223}$$

其中 $\mathrm{vol}(K)$ 是双曲体积，$\mathrm{inj}(K)$ 是单射半径，c 为普适常数。这是纽结理论中的一个新定理，网络的作用是为数学家指出正确的不变量。

重新发现 Jones 多项式。 回忆第 4.3 节：平凡结分类网络自发地使置信度与 Jones 多项式的次数相关 [116]。这是一个已知不变量，作为任务的自然坐标在权重中被重新发现。可解释性有时告诉我们网络找到了已知之物（令人放心），有时告诉我们它找到了未知之物（提供线索）。

程序与智能体。 FunSearch [12] 通过进化由精确验证器评分的程序，找到了创纪录的 cap-set 构造；AlphaEvolve [13] 以相同方式打破了长期保持的矩阵乘法纪录。生成器提出可解释程序，可信验证器对其评分，进化过程不断迭代。这是由第 4.1 节智能体循环驱动的猜想生成，可以应用于弦论中任何存在快速精确检查的地方：一致性条件、指标计算和拓扑不变量。一个适合大家尝试的项目是：挑选一个人们费力手工发现的景观结构，看看程序搜索智能体能否找到它或它的推广。

5 回顾与展望

让我回顾三天的结果并展望未来。

第一天围绕三个支柱构建了神经网络理论。第一个是表达能力：逼近定理表明网络基本上可以表示任何对象。例子包括普适逼近定理，以及 Kolmogorov–Arnold 表示定理；它们至今仍在启发网络架构，如 KAN。注意力和 Transformer 将讨论从固定输入推广到序列；思维链推理表明，表达能力随允许模型生成的 token 数量增长，这是推理模型的驱动力。第二个支柱是统计：一个刚初始化的网络是从系综中抽取的单个样本，而该系综的关联函数是基本对象。大 N 时中心极限定理使系综成为广义自由场（NNGP）；在 $O(1/N)$ 阶或通过破坏统计独立性可恢复相互作用；将变换吸收到参数密度中则可以构造全局对称性。第三个支柱是动力学：梯度下降由神经切线核支配，无限宽时该核冻结，得到精确可解的核回归。明显的限制是冻结核不学习特征，而 μP 标度分析表明如何恢复特征学习。

第二天反转了这一对应关系，用架构和参数密度 $(\phi_\theta, P(\theta))$ 定义场论，其配分函数是对参数而不是场的积分。我们看到，如何通过中心极限定理和谱塑形构造自由理论，如何通过使 $P(\theta)$ 形变并破坏独立性的算符插入引入相互作用，以及如何把量子性化为待构造的 OS 公理清单。后半部分介绍过去一年的结果。普适性指出，缓增分布空间上的每一个分布都是 NN-FT。Liouville 理论被实现为所有相互作用由一个条件零模承载，在百分之几的水平上与 DOZZ 公式吻合。玻色弦在无限宽度下被实现，α' 由输出权重方差设定，Veneziano 和 Virasoro–Shapiro 振幅在参数空间中被重新解析计算。拓扑扇区通过离散潜变量进入，得到涡旋和 BKT 相变。最后，Schwinger–Dyson 方程、Ward 恒等式及反常被表述为参数空间上的流，其中包括通过 NN-FT 模计数推导玻色弦临界维数 $D = 26$。

第三天讨论机器学习用于物理。智能体，即通过工具循环行动的推理模型，只要仔细验证其输出，就显著降低了每种经典技术的实施成本。PINN 通过最小化残差求解几何偏微分方程，弦论中的核心例子是 Calabi–Yau 度规；第一天的 NTK 在这里再次出现，在冻结核极限下把网络度规流与 Ricci 流联系起来。强化学习将景观探索与解结变为学得的搜索，并不仅带来效率，还能产生人类可检查的证书；应用包括 II 型弦论和纽结理论。最后，可解释的监督学习通过生成猜想及后续完善可以导向定理，我们在 F 理论规范扇区和纽结符号数中看到了例子，而程序搜索智能体是其现代变体。

在我看来，我们所处的智能体时代为未来几年指明了方向。第三天的技术由支付了实施时间成本的研究人员开发，而本学校的学生大多将不必支付同样的代价，这会改变单个研究者能够尝试的事情。未来几年，智能体将承担越来越多的研究流程，从文献综合到计算与初步验证；随着形式化和数值检查被纳入其循环，它们会变得更可靠。我也预期，猜想生成将越来越多地依靠智能体，系统可以针对弦论中大量存在的精确、无噪声数据提出、测试并完善候选结构。从繁琐计算中节省的时间，可以重新投入更深入的思考和概念性突破。这样的工作方式是我们许多人成为物理学家的初衷，也是一项值得有意识训练的技能。现在是成为物理学家的激动人心的时代。

致谢。 感谢上海数学与交叉学科研究院及 Pre-Strings 2026 学校的组织者和学生 [14] 的邀请，以及在上海度过的充满活力的时光。这些讲座依赖许多朋友和合作者的工作及交流，尤其是第二天 NN-FT 成果方面的 Mehmet Demirtas、Christian Ferko、Sam Frank、Vishnu Jejjala、Anindita Maiti、Brandon Robinson、Fabian Ruehle、Matt Schwartz 和 Keegan Stoner；第一天机器学习

理论方面的 Yasaman Bahri、Cengiz Pehlevan 和 Greg Yang；以及在全文其他工作中出现的许多人士。感谢 Christian Ferko、Sam Frank 和 Fabian Ruehle 阅读这些讲义的部分草稿。讲义中介绍的我的工作得到美国国家科学基金会 CAREER 项目 PHY-1848089、项目 PHY-2209903 和合作协议 PHY-2019786（NSF 人工智能与基础相互作用研究所），以及 Simons 学习物理与神经计算合作项目的支持。感谢 Physical Superintelligence 的同事就智能体式人工智能用于物理进行讨论和合作。秉承这些方法和第三天讲座的精神，我与 Claude Fable 5 合作起草了这些讲义，之后花了许多小时添加和润色内容；其中一部分来自我的 TASI 讲义。选择双栏横向排版是为了方便板书，同时也因为它仍然易于阅读；致意文献 [163]。

说明。 我在学校结束后不久发布这些讲义，因此文中的笔误肯定比理想情况多，参考文献也比理想情况少；欢迎提出更正，我会在更新中纳入。我采用了轻松的语气，因为讲座应该有趣，但某些地方可能做得过头。许多结果的处理不可避免地很精简，请读者参阅原始论文。

A 中心极限定理

让我们快速回顾中心极限定理（CLT）的一种推导，因为宽神经网络的统计依赖于它。取随机变量之和

$$\phi = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} X_i, \tag{224}$$

其中 $\langle X_i \rangle = 0$。矩 μ_r 和累积量 κ_r 分别来自矩生成函数（配分函数）$Z[J] = \langle e^{J\phi} \rangle$ 和累积量生成函数 $W[J] = \log Z[J]$：

$$\mu_r = \left(\frac{d}{dJ} \right)^r Z[J] \Big|_{J=0}, \tag{225}$$

$$\kappa_r = \left(\frac{d}{dJ} \right)^r W[J] \Big|_{J=0}. \tag{226}$$

对于独立的 X_i，配分函数分解为 $Z_{\sum_i X_i}[J] = \prod_i Z_{X_i}[J]$，因此累积量生成函数相加：

$$W_{\sum_i X_i}[J] = \sum_i W_{X_i}[J], \tag{227}$$

$$\kappa_r^{\sum X_i} = \sum_i \kappa_r^{X_i}. \tag{228}$$

如果 X_i 还同分布，那么所有 $\kappa_r^{X_i}$ 相同；考虑 $1/\sqrt{N}$ 的归一化，得到

$$\kappa_r^{\phi} = \frac{\kappa_r^{X_i}}{N^{r/2-1}}, \tag{229}$$

于是

$$\lim_{N \to \infty} \kappa_{r>2}^{\phi} = 0. \tag{230}$$

高阶累积量消失正是高斯性。用物理语言说：累积量是连通关联函数，而式 (230) 表明自由理论没有高阶连通关联函数。

这一推导揭示了产生非高斯性的恰好两种方式：

- $1/N$ **修正**：有限 N 时可在 κ_r^{ϕ} 中看见。
- **独立性破缺**：因为证明依赖式 (227)。

这两种方法都将在本讲义中反复使用。

译注：原文中的约定与推导疑点

以下说明由译本审校补充，并非作者讲义的一部分。

所引页码和式号均指冻结英文 PDF，版本为 arXiv:2607.02905v1。

正文保留其原式与论断。这些说明区分可直接检验的代数问题与讲义省略的条件，不替代对参考论文中完整定理的审查或数值复现。

1. **普适逼近定理与正性条件（原第 5–6 页）**。讲义将非多项式激活函数的概括性陈述称为 Cybenko 原始版本，但没有在这一表述中列出激活函数的正则性条件。应区分原始 sigmoid 型结论与后来的非多项式推广，不能把它读作对任意无正则性的函数均成立。式 (26) 的 $e^{\log x+\log y}$ 要求实数 $x, y > 0$；随后的多项式恒等式 (27) 没有这一限制。

2. **注意力掩码与查询 / 键重参数化（原第 7–8 页）**。A 在式 (28) 中定义为 softmax 后的矩阵，而因果掩码实际作用于 softmax 前的分数，不能把后者等同于已经归一化的 A。在 $Q = XW_Q, K = XW_K$ 的约定下，分数涉及 $W_Q W_K^T$；一般左乘 R 不保持它。即使只看原文所称的 $W_Q^T W_K$，同一左乘也需 $R^T R = I$ 等条件。这一问题同样影响原第 28 页再次出现的表述；正文及已有脚注保留原说法并提示其条件。

3. **NNGP 与中心极限定理的适用条件（原第 9–10、42 页）**。零均值、有限方差的独立同分布变量的标量 CLT，并不需要矩生成函数在零附近存在；而附录使用矩生成函数及所有高阶累积量的推导，只适用于这些量确有定义的情形。类似地，输出权重有有限方差，还不足以单独保证每个非线性神经元的二阶矩有限。对有限个输入的联合高斯极限、函数空间上的弱收敛及形式作用量的逆，需要分别说明矩条件、拓扑与可逆性。原文是简略讲义表述。

4. **Gauss-net 的大小写与四点函数指数（原第 12 页）**。式 (64) 使用 σ_{W_0}，而架构与两点函数用 σ_{w0}，原文没有区分二者。若视为同一方差，取四个输入全部为 x，直接对高斯输出权重条件平均，可得

$$G_c^{(4)}(x,x,x,x) = \frac{3\sigma_{w_1}^4}{4N}\left[\exp\left(4\sigma_{b_0}^2 + \frac{4\sigma_{w_0}^2}{d}\|x\|^2\right) - 1\right].$$

   这是高斯混合方差的涨落，非负。原式 (67) 的指数分组与符号不能复现这一同点检验：取 $\sigma_{b_0} = 0$、非零 x，按其正的点积项解释会得到负的四阶连通函数。疑式及其置换记法均在正文原样保留。

5. **Scalar-net 的动量支持（原第 13、19 页）**。隐藏权重从有限球 B_Λ^d 抽取时，传播子只在 $|p| \le \Lambda$ 的支持内为 $1/(p^2+m^2)$，球外为零（边界约定不影响通常积分）。式 (77) 及第二天的重复表达省略了这一截止；全动量空间的自由标量传播子还需说明去截止极限。

6. **单隐藏层 NTK 的展开（原第 15 页）**。式 (91) 将 j 求和置于激活函数内，式 (93)–(94) 却对单个 $w_{ij}^{(0)}x_j$ 先取激活，再求和。对一般非线性函数，这两者不同。令 $a_i(x) = \sum_j w_{ij}^{(0)}x_j$，由式 (91) 直接求导得到

$$\Theta(x,x') = \frac{1}{N}\sum_i \left[\sigma(a_i(x))\sigma(a_i(x')) + (w_i^{(1)})^2(x\cdot x')\sigma'(a_i(x))\sigma'(a_i(x'))\right].$$

例如 $N=1, d=2, \sigma(t)=t^2, w^{(0)}=(1,1), w^{(1)}=1, x=x'=(1,-1)$ 时，真实梯度及 NTK 均为零，而按原式单项展开得到 $4+8=12$。正文没有将原式改为此处的核查表达式。

7. **冻结核精确解与特征学习标度（原第 15–17 页）**。式 (99)–(102) 直接使用训练集核矩阵的逆；完整拟合与长时间极限需相应的可逆性 / 正谱条件。奇异核可用投影与广义逆表述，不能无条件宣布任意标签均被拟合。式 (119) 的首项下标为 μ,ν，其他项为 α, x，且左侧有 η_0 而右侧没有；式 (129)–(130) 又写 c_ℓ，前文学习率定义的是全局 c。这些是原文记号问题。文中无限宽冻结核的陈述应依其参数化和学习率范围理解，不能推广为所有无限宽标度都无特征学习。

8. **OS 条件与 Borel 普适性的范围（原第 19–21 页）**。原文明确把点式反射正性不等式称为必要形式；它不替代对一般测试函数及其线性组合所需的反射正性条件。标准 Borel 空间之间并非无条件全部同构：例如单点空间与实线不同构；通常的同构定理要求同等基数，特别是任意两个不可数标准 Borel 空间同构。这里指定的两个无限空间不因此被否定，但讲义的泛化句省略了条件。以 Borel 同构作为架构给出的是可测存在性，不自动给出有限神经网络、有效算法、逼近速率或可训练性。

9. **Liouville 零模条件密度的归一化（原第 22 页）**。取 $s>0, M_X>0$，零模积分满足

$$\int_0^\infty t^{s-1}e^{-M_X t}\,dt=\Gamma(s)M_X^{-s}.$$

因此将其当成归一化 Gamma 条件密度时，归一化因子依赖非零模。若直接从独立高斯非零模及归一化条件密度采样，原未归一化相关函数还需要相应的 M_X^{-s} 权重及顶点插入因子；这些不能由比例符号自动消失。讲义所说 “相互作用完全位于零模” 应结合这一采样 / 重加权约定理解；M_X 本身依赖非零模。正文保留讲义说明，不声称已经复现 DOZZ 数值。

10. **零模高斯分布与 delta 函数（原第 24 页）**。未归一化的 $\exp(-\sigma_{\text{eff}}^2 p^2/2)$ 在 $\sigma_{\text{eff}}\to\infty$ 时不直接趋于非零 delta 分布；它的积分趋于零。标准分布极限为

$$\left(\frac{\sigma_{\text{eff}}}{\sqrt{2\pi}}\right)^D e^{-\sigma_{\text{eff}}^2\|p\|^2/2}\longrightarrow\delta^{(D)}(p).$$

原文振幅中还需追踪零模体积或顶点归一化如何承担这一因子。保留原振幅及其红外 / 紫外极限叙述，不静默补入未声明的归一化。

11. **BKT 架构的截止、净荷与刚度（原第 25–26 页）**。在二维整数动量上，$1/|n|^2$ 权重需排除零模，并设定紫外截止才能成为可直接采样的归一化概率；讲义未在该式中展开。环面上的涡旋还需周期边界与相应 Green 函数约定。$\sum_a m_a=0$ 是净涡旋荷为零，允许非零总涡旋数 N_v，不能将原文 “总涡旋数为零” 理解为没有涡旋。此外，裸的无量纲刚度 $K_0=\rho_{s,0}/T$、重整化刚度与有量纲的螺旋模量需要区分；不能仅凭自旋波关系推断一般有限逸度的完整模型精确临界温度。正文原数值及图表按作者报告保留，没有声称独立复现。

12. **输入旋转的补偿流符号（原第 28 页）**。若输入变为 $x\mapsto(I+\epsilon\omega)x$，要逐个保持 $z=Wx+b$ 不变，参数需变为 $W\mapsto W-\epsilon W\omega$。原文所写流为 $+W\omega$，与所声明输入变换同时使用时

会使一阶改变量相加。取反流后，高斯密度的破缺函数仍为零，因此这项符号问题不否定所述高斯系综的旋转不变性。

13. **Ward 形式体系与 Weyl 模计数（原第 27–29 页）**。主恒等式来自分部积分，须保留原文已注明的边界通量条件；由参数空间流恢复局域时空流，还需局域拉格朗日描述等条件。式 (189) 的玻色子求和从 $\ell = 0$ 开始，但所写方差在零模处分母为零；该模须另行规定。给定原文的谱 zeta 值 $-2/3$ 和 $-5/3$ 后，式 (194) 确实化为 $-(D-26)/3$；这一代数核查不是对整个鬼场测度、Weyl 变化和正则化推导的独立证明。

14. **Calabi–Yau 形式的因子与正定性（原第 32–34 页）**。按正文 $J = i\partial\bar{\partial}K$ 的约定，实势的修正相应应带 i；讲义的 $J_{\mathrm{CY}} = J_{\mathrm{ref}} + \partial\bar{\partial}\phi$ 与随后度规式之间省略了这一因子。闭的 $(1,1)$ 形式及固定同调类也不单独保证正定性，仍需限制在 Kähler 锥中。对于标准 Kähler 形式，复维二子流形的标定体积形式是 $J^2/2!$；原第 32 页只写 $J \wedge J$，其归一化需明确。上述均为原文的约定 / 条件问题，正文不作静默修正。

15. **Ricci 流的限制与解结证书（原第 34、39 页）**。 Perelman 泛函是全局泛函，而讲义此前的 ℓ 是逐点损失；从一般网络度规流得到 Perelman 形式的 Ricci 流，还需要指定泛函梯度所用的度规、测度及辅助场的演化。该简略对应不应当成任意网络训练自动等同 Ricci 流。另一个独立的约定问题是：B_n 中的空辫词闭合为 n 分量平凡链环；要由空词给出平凡结证书，须同时追踪 Markov 去稳定化，最终到达一股辫上的空词。原文的证书陈述须含这一股数信息。

16. **作者的时间性陈述**。关于 2026 年人工智能能力、文献中的数值性能、工具版本、猜想历史与研究结果，均按作者在 2026 年 7 月的陈述翻译。译本核对其可见原文、归属与限定语，没有将翻译升级为这些外部结果的独立事实核查、实验复现或证明认证。

17. **参考文献的源文件恢复**。原 PDF 第 48 页文献 [116] 将姓名显示为 Sulkowski，作者源文件为 Sułkowski；译本保留源文件的姓名拼写。原第 49 页文献 [133] 的长网址在页右边界被截断，译本据作者同版本 `.bbl` 恢复完整链接 `https://onlinelibrary.wiley.com/doi/pdf/10.1002/cpa.3160310304`。这些恢复不构成对外部文献内容的核实。

参考文献

[1] J. Halverson, *TASI lectures on physics for machine learning*, 2024. https://arxiv.org/abs/2408.00082.

[2] W. Isaacson, *The Innovators: How a Group of Hackers, Geniuses, and Geeks Created the Digital Revolution*. Simon & Schuster, New York, first simon & schuster hardcover edition ed., 2014.

[3] OpenAI, :, A. Jaech, A. Kalai, A. Lerer, A. Richardson et al., *OpenAI o1 system card*, 2026. https://arxiv.org/abs/2412.16720.

[4] DeepSeek-AI, D. Guo, D. Yang, H. Zhang, J. Song, P. Wang et al., *DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning*, 2026. https://doi.org/10.1038/s41586-025-09422-z, https://arxiv.org/abs/2501.12948.

[5] Google DeepMind, *Advanced version of Gemini with Deep Think officially achieves gold-medal standard at the international mathematical olympiad*, July, 2025. https://deepmind.google/discover/blog/advanced-version-of-gemini-with-deep-think-officially-achieves-gold-medal-standard-at-the-international-mathematical-olympiad/.

[6] D. E. Béchard, "OpenAI model earns gold-medal score at international math olympiad and advances path to artificial general intelligence." Scientific American, 2025. https://www.scientificamerican.com/article/openai-model-earns-gold-medal-score-at-international-math-olympiad-and/.

[7] T. F. Bloom, "The Erdős problems project." https://www.erdosproblems.com.

[8] OpenAI, *An OpenAI model has disproved a central conjecture in discrete geometry*, 2026. https://openai.com/index/model-disproves-discrete-geometry-conjecture/.

[9] N. Alon, T. F. Bloom, W. T. Gowers, D. Litt, W. Sawin, A. Shankar et al., *Remarks on the disproof of the unit distance conjecture*, 2605.20695.

[10] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan et al., *React: Synergizing reasoning and acting in language models*, 2023. https://arxiv.org/abs/2210.03629.

[11] Anthropic, *Claude Code*, 2025. https://claude.com/claude-code.

[12] B. Romera-Paredes, M. Barekatain, A. Novikov, M. Balog, M. P. Kumar, E. Dupont et al., *Mathematical discoveries from program search with large language models*, *Nature* **625** (2024) 468.

[13] A. Novikov, N. Vũ, M. Eisenberger, E. Dupont, P.-S. Huang, A. Z. Wagner et al., *Alphaevolve: A coding agent for scientific and algorithmic discovery*, 2025. https://arxiv.org/abs/2506.13131.

[14] *Pre-strings school 2026*, 2026. https://www.pre-strings2026.com/.

[15] H. Robbins and S. Monro, "A Stochastic Approximation Method." Annals of Mathematical Statistics, 1951. 10.1214/aoms/1177729586, https://doi.org/10.1214/aoms/1177729586.

[16] F. Rosenblatt, *The perceptron: a probabilistic model for information storage and organization in the brain.*, *Psychological review* **65 6** (1958) 386.

[17] D. P. Kingma and J. Ba, *Adam: A method for stochastic optimization*, 2017. https://arxiv.org/abs/1412.6980.

[18] G. B. D. Luca and E. Silverstein, *Born-infeld (BI) for AI: Energy-conserving descent (ECD) for optimization*, 2022. https://arxiv.org/abs/2201.11137.

[19] G. B. D. Luca, A. Gatti and E. Silverstein, *Improving energy conserving descent for machine learning: Theory and practice*, 2023. https://arxiv.org/abs/2306.00352.

[20] G. Cybenko, "Approximation by Superpositions of a Sigmoidal Function." Mathematics of Control, Signals and Systems, 1989. 10.1007/BF02551274, https://doi.org/10.1007/bf02551274.

[21] K. Hornik, M. Stinchcombe and H. White, *Approximation capabilities of multilayer feedforward networks*, *Neural Networks* **4** (1991) 251.

[22] A. N. Kolmogorov, *On the representation of continuous functions of several variables by superpositions of continuous functions of one variable and addition*, *Doklady Akademii Nauk SSSR* **114** (1957) 953.

[23] V. I. Arnold, *On functions of three variables*, *Doklady Akademii Nauk SSSR* **114** (1957) 679.

[24] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić et al., *Kan: Kolmogorov-arnold networks*, 2025. https://arxiv.org/abs/2404.19756.

[25] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez et al., *Attention is all you need*, 2023. https://arxiv.org/abs/1706.03762.

[26] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal et al., *Language models are few-shot learners*, 2020. https://arxiv.org/abs/2005.14165.

[27] C. Yun, S. Bhojanapalli, A. S. Rawat, S. J. Reddi and S. Kumar, *Are transformers universal approximators of sequence-to-sequence functions?*, 2020. https://arxiv.org/abs/1912.10077.

[28] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia et al., *Chain-of-thought prompting elicits reasoning in large language models*, 2023. https://arxiv.org/abs/2201.11903.

[29] W. Merrill and A. Sabharwal, *The expressive power of transformers with chain of thought*, 2024. https://arxiv.org/abs/2310.07923.

[30] G. Feng, B. Zhang, Y. Gu, H. Ye, D. He and L. Wang, *Towards revealing the mystery behind chain of thought: A theoretical perspective*, 2023. https://arxiv.org/abs/2305.15408.

[31] R. M. Neal, *Bayesian learning for neural networks*, *Lecture Notes in Statistics* **118** (1996) .

[32] C. K. Williams, *Computing with infinite networks*, *Advances in neural information processing systems* (1996) .

[33] A. Krizhevsky, I. Sutskever and G. E. Hinton, *Imagenet classification with deep convolutional neural networks*, in *Advances in Neural Information Processing Systems* (F. Pereira, C. Burges, L. Bottou and K. Weinberger, eds.), vol. 25, Curran Associates, Inc., 2012, https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.

[34] G. Yang, *Tensor programs i: Wide feedforward or recurrent neural networks of any architecture are gaussian processes*, 2021. https://arxiv.org/abs/1910.12478.

[35] M. Demirtas, J. Halverson, A. Maiti, M. D. Schwartz and K. Stoner, *Neural network field theories: Non-gaussianity, actions, and locality*, 2023. https://arxiv.org/abs/2307.03223.

[36] T. S. Cohen and M. Welling, *Group equivariant convolutional networks*, 2016. https://arxiv.org/abs/1602.07576.

[37] M. Winkels and T. S. Cohen, *3D G-CNNs for pulmonary nodule detection*, 2018. https://arxiv.org/abs/1804.04656.

[38] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child et al., *Scaling laws for neural language models*, 2020. https://arxiv.org/abs/2001.08361.

[39] S. Batzner, A. Musaelian, L. Sun, M. Geiger, J. P. Mailoa, M. Kornbluth et al., *E(3)-equivariant graph neural networks for data-efficient and accurate interatomic potentials*, 2021. https://doi.org/10.1038/s41467-022-29939-5, https://arxiv.org/abs/2101.03164.

[40] N. Frey, R. Soklaski, S. Axelrod, S. Samsi, R. Gomez-Bombarelli, C. Coley et al., *Neural scaling of deep chemical models*, *ChemRxiv* (2022) .

[41] D. Boyda, G. Kanwar, S. Racanière, D. J. Rezende, M. S. Albergo, K. Cranmer et al., *Sampling using $su(n)$ gauge equivariant flows*, 2020. https://doi.org/10.1103/PhysRevD.103.074504, https://arxiv.org/abs/2008.05456.

[42] A. Maiti, K. Stoner and J. Halverson, *Symmetry-via-duality: Invariant neural network densities from parameter-space correlators*, 2021. https://arxiv.org/abs/2106.00694.

[43] J. Halverson, A. Maiti and K. Stoner, *Neural networks and quantum field theory*, 2021. https://doi.org/10.1088/2632-2153/abeca3, https://arxiv.org/abs/2008.08601.

[44] J. Halverson, *Building quantum field theories out of neurons*, 2021. https://arxiv.org/abs/2112.04527.

[45] A. Jacot, F. Gabriel and C. Hongler, *Neural tangent kernel: Convergence and generalization in neural networks*, 2020. https://arxiv.org/abs/1806.07572.

[46] J. Lee, L. Xiao, S. S. Schoenholz, Y. Bahri, R. Novak, J. Sohl-Dickstein et al., *Wide neural networks of any depth evolve as linear models under gradient descent*, 2019. https://doi.org/10.1088/1742-5468/abc62b, https://arxiv.org/abs/1902.06720.

[47] C. Pehlevan and B. Bordelon, *Lecture notes on infinite-width limits of neural networks*, August, 2024. https://mlschool.princeton.edu/events/2023/pehlevan.

[48] G. Yang and E. J. Hu, *Feature learning in infinite-width neural networks*, 2022. https://arxiv.org/abs/2011.14522.

[49] B. Bordelon and C. Pehlevan, *Self-consistent dynamical field theory of kernel evolution in wide neural networks*, 2022. https://arxiv.org/abs/2205.09653.

[50] D. A. Roberts, S. Yaida and B. Hanin, *The principles of deep learning theory*, 2021. https://doi.org/10.1017/9781009023405, https://arxiv.org/abs/2106.10165.

[51] S. Yaida, *Meta-principled family of hyperparameter scaling strategies*, 2022. https://arxiv.org/abs/2210.04909.

[52] S. S. Schoenholz, J. Gilmer, S. Ganguli and J. Sohl-Dickstein, *Deep information propagation*, 2017. https://arxiv.org/abs/1611.01232.

[53] S. Frank, J. Halverson, A. Maiti and F. Ruehle, *Fermions and supersymmetry in neural network field theories*, 2025. https://arxiv.org/abs/2511.16741.

[54] K. Osterwalder and R. Schrader, *Axioms for Euclidean Green's Functions*, *Commun. Math. Phys.* **31** (1973) 83.

[55] D. Simmons-Duffin, *TASI lectures on the conformal bootstrap*, 2016. https://arxiv.org/abs/1602.07982.

[56] C. Ferko and J. Halverson, *Quantum mechanics and neural networks*, 2025. https://arxiv.org/abs/2504.05462.

[57] J. Halverson, J. Naskar and J. Tian, *Conformal fields from neural networks*, 2025. https://doi.org/10.1007/JHEP10(2025)039, https://arxiv.org/abs/2409.12222.

[58] B. Robinson, *Virasoro symmetry in neural network field theories*, 2026. https://arxiv.org/abs/2512.24420.

[59] P. Capuozzo, B. Robinson and B. Suzzoni, *Conformal defects in neural network field theories*, 2026. https://doi.org/10.1007/JHEP05(2026)124, https://arxiv.org/abs/2512.07946.

[60] C. Ferko, S. Frank, J. Halverson and V. Jejjala, *Anomalies in neural network field theory*, 2026. https://arxiv.org/abs/2605.12488.

[61] F. David, A. Kupiainen, R. Rhodes and V. Vargas, *Liouville quantum gravity on the riemann sphere*, 2015. https://arxiv.org/abs/1410.7318.

[62] Simons Collaboration on Probabilistic Paths to Quantum Field Theory, "Probabilistic paths to Quantum Field Theory." https://probabilistic-qft.org/, 2026.

[63] M. Jiang, B. P. Czajka, E. B. James, A. J. Hardaway, C. D. Achammer, Q. Su et al., *Neural network approach to dirac quantum field theory*, *Phys. Rev. A* **112** (2025) 062223.

[64] J. N. Howard, M. S. Klinger, A. Maiti and A. G. Stapleton, *Bayesian rg flow in neural network field theories*, 2025. https://doi.org/10.21468/SciPostPhysCore.8.1.027, https://arxiv.org/abs/2405.17538.

[65] D. S. Ageev and Y. A. Ageeva, *Neural network quantum field theory from transformer architectures*, 2026. https://arxiv.org/abs/2602.10209.

[66] Z. Zhang, *Optimal architecture and fundamental bounds in neural network field theory*, 2026. https://arxiv.org/abs/2604.27050.

[67] C. Ferko, J. Halverson and A. Mutchler, *Universality of neural network field theory*, 2026. https://arxiv.org/abs/2601.14453.

[68] S. Frank and J. Halverson, *String theory from infinite width neural networks*, 2026. https://arxiv.org/abs/2601.06249.

[69] C. Ferko, J. Halverson, V. Jejjala and B. Robinson, *Topological effects in neural network field theory*, 2026. https://arxiv.org/abs/2604.02313.

[70] H. Dorn and H. J. Otto, *Two and three-point functions in liouville theory*, 1994. https://doi.org/10.1016/0550-3213(94)00352-1, https://arxiv.org/abs/hep-th/9403141.

[71] A. B. Zamolodchikov and A. B. Zamolodchikov, *Structure constants and conformal bootstrap in liouville field theory*, 1995. https://doi.org/10.1016/0550-3213(96)00351-3, https://arxiv.org/abs/hep-th/9506136.

[72] S. Chatterjee and E. Witten, *Liouville theory: An introduction to rigorous approaches*, 2024. https://arxiv.org/abs/2404.02001.

[73] Y. Song and S. Ermon, *Generative modeling by estimating gradients of the data distribution*, 2020. https://arxiv.org/abs/1907.05600.

[74] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon and B. Poole, *Score-based generative modeling through stochastic differential equations*, 2021. https://arxiv.org/abs/2011.13456.

[75] J. Sohl-Dickstein, E. A. Weiss, N. Maheswaranathan and S. Ganguli, *Deep unsupervised learning using nonequilibrium thermodynamics*, 2015. https://arxiv.org/abs/1503.03585.

[76] E. T. Newman and R. Penrose, *Note on the Bondi-Metzner-Sachs group*, *J. Math. Phys.* **7** (1966) 863.

[77] J. N. Goldberg, A. J. Macfarlane, E. T. Newman, F. Rohrlich and E. C. G. Sudarshan, *Spin-s spherical harmonics and* ð, *J. Math. Phys.* **8** (1967) 2155.

[78] Y.-H. He, *Deep-learning the landscape*, 2018. https://arxiv.org/abs/1706.02714.

[79] D. Krefl and R.-K. Seong, *Machine learning of calabi-yau volumes*, 2017. https://doi.org/10.1103/PhysRevD.96.066014, https://arxiv.org/abs/1706.03346.

[80] F. Ruehle, *Evolving neural networks with genetic algorithms to study the string landscape*, 2017. https://doi.org/10.1007/JHEP08(2017)038, https://arxiv.org/abs/1706.07024.

[81] J. Carifio, J. Halverson, D. Krioukov and B. D. Nelson, *Machine learning in the string landscape*, 2017. https://doi.org/10.1007/JHEP09(2017)157, https://arxiv.org/abs/1707.00655.

[82] F. Ruehle, *Data science applications to string theory*, *Physics Reports* **839** (2020) 1.

[83] Y.-H. He, *The calabi-yau landscape: from geometry, to physics, to machine-learning*, 2020. https://arxiv.org/abs/1812.02893.

[84] S. Gukov, J. Halverson and F. Ruehle, *Rigor with machine learning from field theory to the poincaré conjecture*, 2024. https://arxiv.org/abs/2402.13321.

[85] K. Bull, Y.-H. He, V. Jejjala and C. Mishra, *Machine learning cicy threefolds*, 2018. https://doi.org/10.1016/j.physletb.2018.08.008, https://arxiv.org/abs/1806.03121.

[86] H. Erbin and R. Finotello, *Machine learning for complete intersection calabi-yau manifolds: a methodological study*, 2021. https://doi.org/10.1103/PhysRevD.103.126014, https://arxiv.org/abs/2007.15706.

[87] D. Klaewer and L. Schlechter, *Machine learning line bundle cohomologies of hypersurfaces in toric varieties*, 2018. https://doi.org/10.1016/j.physletb.2019.01.002, https://arxiv.org/abs/1809.02547.

[88] C. R. Brodie, A. Constantin, R. Deen and A. Lukas, *Machine learning line bundle cohomology*, 2019. https://doi.org/10.1002/prop.201900087, https://arxiv.org/abs/1906.08730.

[89] R. Deen, Y.-H. He, S.-J. Lee and A. Lukas, *Machine learning string standard models*, 2020. https://arxiv.org/abs/2003.13339.

[90] K. Hashimoto, S. Sugishita, A. Tanaka and A. Tomiya, *Deep learning and ads/cft*, 2018. https://doi.org/10.1103/PhysRevD.98.046019, https://arxiv.org/abs/1802.08313.

[91] E. Choi and R.-K. Seong, *Machine learning regularization for the minimum volume formula of toric calabi-yau 3-folds*, 2023. https://doi.org/10.1103/PhysRevD.109.046015, https://arxiv.org/abs/2310.19276.

[92] S. Gukov and R.-K. Seong, *Learning bps spectra and the gap conjecture*, 2024. https://doi.org/10.1103/PhysRevD.110.046016, https://arxiv.org/abs/2405.09993.

[93] J. Halverson, B. Nelson and F. Ruehle, *Branes with brains: Exploring string vacua with deep reinforcement learning*, 2019. https://doi.org/10.1007/JHEP06(2019)003, https://arxiv.org/abs/1903.11616.

[94] A. Cole, A. Schachner and G. Shiu, *Searching the landscape of flux vacua with genetic algorithms*, 2019. https://doi.org/10.1007/JHEP11(2019)045, https://arxiv.org/abs/1907.10072.

[95] S. Krippendorf, R. Kroepsch and M. Syvaeri, *Revealing systematics in phenomenologically viable flux vacua with reinforcement learning*, 2021. https://arxiv.org/abs/2107.04039.

[96] A. Cole, S. Krippendorf, A. Schachner and G. Shiu, *Probing the structure of string theory vacua with genetic algorithms and reinforcement learning*, 2021. https://arxiv.org/abs/2111.11466.

[97] S. Abel and J. Rizos, *Genetic algorithms and the search for viable string vacua*, 2014. https://doi.org/10.1007/JHEP08(2014)010, https://arxiv.org/abs/1404.7359.

[98] A. Constantin, T. R. Harvey and A. Lukas, *Heterotic string model building with monad bundles and reinforcement learning*, 2021. https://doi.org/10.1002/prop.202100186, https://arxiv.org/abs/2108.07316.

[99] S. Abel, A. Constantin, T. R. Harvey and A. Lukas, *Evolving heterotic gauge backgrounds: Genetic algorithms versus reinforcement learning*, 2021. https://doi.org/10.1002/prop.202200034, https://arxiv.org/abs/2110.14029.

[100] S. Abel, A. Constantin, T. R. Harvey and A. Lukas, *String model building, reinforcement learning and genetic algorithms*, 2021. https://arxiv.org/abs/2111.07333.

[101] P. Berglund, Y.-H. He, E. Heyes, E. Hirst, V. Jejjala and A. Lukas, *New calabi-yau manifolds from genetic algorithms*, 2024. https://doi.org/10.1016/j.physletb.2024.138504, https://arxiv.org/abs/2306.06159.

[102] T. He, J. Lee and H. Ooguri, *Exploring the holographic entropy cone via reinforcement learning*, 2026. https://doi.org/10.1007/JHEP06(2026)267, https://arxiv.org/abs/2601.19979.

[103] T. R. Harvey and A. Lukas, *Particle physics model building with reinforcement learning*, 2021. https://arxiv.org/abs/2103.04759.

[104] M. C. N. Cheng, V. Anagiannis, M. Weiler, P. de Haan, T. S. Cohen and M. Welling, *Covariance in physics and convolutional neural networks*, 2019. https://arxiv.org/abs/1906.02481.

[105] S. Krippendorf and M. Syvaeri, *Detecting symmetries with neural networks*, 2020. https://arxiv.org/abs/2003.13679.

[106] J. Halverson and C. Long, *Statistical predictions in string theory and deep generative models*, 2020. https://doi.org/10.1002/prop.202000005, https://arxiv.org/abs/2001.00555.

[107] A. Ashmore, Y.-H. He and B. Ovrut, *Machine learning calabi-yau metrics*, 2020. https://doi.org/10.1002/prop.202000068, https://arxiv.org/abs/1910.08605.

[108] M. R. Douglas, S. Lakshminarasimhan and Y. Qi, *Numerical calabi-yau metrics from holomorphic networks*, 2021. https://arxiv.org/abs/2012.04797.

[109] L. B. Anderson, M. Gerdes, J. Gray, S. Krippendorf, N. Raghuram and F. Ruehle, *Moduli-dependent calabi-yau and su(3)-structure metrics from machine learning*, 2021. https://arxiv.org/abs/2012.04656.

[110] V. Jejjala, D. K. M. Pena and C. Mishra, *Neural network approximations for calabi-yau metrics*, 2021. https://arxiv.org/abs/2012.15821.

[111] M. Larfors, A. Lukas, F. Ruehle and R. Schneider, *Learning size and shape of calabi-yau spaces*, 2021. https://arxiv.org/abs/2111.01436.

[112] M. Larfors, A. Lukas, F. Ruehle and R. Schneider, *Numerical metrics for complete intersection and kreuzer-skarke calabi-yau manifolds*, 2022. https://arxiv.org/abs/2205.13408.

[113] M. Gerdes and S. Krippendorf, *Cyjax: A package for calabi-yau metrics with jax*, 2023. https://doi.org/10.1088/2632-2153/acdc84, https://arxiv.org/abs/2211.12520.

[114] V. Jejjala, A. Kar and O. Parrikar, *Deep learning the hyperbolic volume of a knot*, 2019. https://doi.org/10.1016/j.physletb.2019.135033, https://arxiv.org/abs/1902.05547.

[115] J. Craven, M. Hughes, V. Jejjala and A. Kar, *Learning knot invariants across dimensions*, 2022. https://doi.org/10.21468/SciPostPhys.14.2.021, https://arxiv.org/abs/2112.00016.

[116] S. Gukov, J. Halverson, F. Ruehle and P. Sułkowski, *Learning to unknot*, 2020. https://arxiv.org/abs/2010.16263.

[117] A. Davies, P. Veličković, L. Buesing, S. Blackwell, D. Zheng, N. Tomašev et al., *Advancing mathematics by guiding human intuition with AI*, *Nature* **600** (2021) 70.

[118] S. Gukov, J. Halverson, C. Manolescu and F. Ruehle, *Searching for ribbons with machine learning*, 2025. https://arxiv.org/abs/2304.09304.

[119] D. A. Boiko, R. MacKnight, B. Kline and G. Gomes, *Autonomous chemical research with large language models*, *Nature* **624** (2023) 570.

[120] C. Lu, C. Lu, R. T. Lange, J. Foerster, J. Clune and D. Ha, *The AI scientist: Towards fully automated open-ended scientific discovery*, 2024. https://arxiv.org/abs/2408.06292.

[121] A. Ghafarollahi and M. J. Buehler, *Sciagents: Automating scientific discovery through multi-agent intelligent graph reasoning*, 2024. https://arxiv.org/abs/2409.05556.

[122] Physical Superintelligence PBC, *Get Physics Done (GPD): the first open-source agentic AI physicist*, 2026. https://github.com/psi-oss/get-physics-done.

[123] D. Amodei, C. Olah, J. Steinhardt, P. Christiano, J. Schulman and D. Mané, *Concrete problems in AI safety*, 2016. https://arxiv.org/abs/1606.06565.

[124] J. Skalse, N. H. R. Howe, D. Krasheninnikov and D. Krueger, *Defining and characterizing reward hacking*, 2025. https://arxiv.org/abs/2209.13085.

[125] M. Raissi, P. Perdikaris and G. E. Karniadakis, *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*, *Journal of Computational Physics* **378** (2018) .

[126] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang and L. Yang, *Physics-informed machine learning*, *Nature Reviews Physics* **3** (2021) .

[127] D. Platt, *Non-uniqueness and symmetries for the nirenberg problem using computer assistance*, 2026. https://arxiv.org/abs/2603.29544.

[128] Y. Wang, M. Bennani, J. Martens, S. Racanière, S. Blackwell, A. Matthews et al., *Discovery of unstable singularities*, 2025. https://arxiv.org/abs/2509.14185.

[129] G. Carleo and M. Troyer, *Solving the quantum many-body problem with artificial neural networks*, 2016. https://doi.org/10.1126/science.aag2302, https://arxiv.org/abs/1606.02318.

[130] D. Pfau, J. S. Spencer, A. G. de G. Matthews and W. M. C. Foulkes, *Ab-initio solution of the many-electron schrödinger equation with deep neural networks*, 2021. https://doi.org/10.1103/PhysRevResearch.2.033429, https://arxiv.org/abs/1909.02487.

[131] J. Hermann, Z. Schätzle and F. Noé, *Deep neural network solution of the electronic schrödinger equation*, 2020. https://doi.org/10.1038/s41557-020-0544-y, https://arxiv.org/abs/1909.08423.

[132] M. Hibat-Allah, M. Ganahl, L. E. Hayward, R. G. Melko and J. Carrasquilla, *Recurrent neural network wave functions*, 2020. https://doi.org/10.1103/PhysRevResearch.2.023358, https://arxiv.org/abs/2002.02973.

[133] S.-T. Yau, *On the ricci curvature of a compact kähler manifold and the complex monge-ampére equation, i*, *Communications on Pure and Applied Mathematics* **31** (1978) 339 [https://onlinelibrary.wiley.com/doi/pdf/10.1002/cpa.3160310304].

[134] M. Kreuzer and H. Skarke, *Complete classification of reflexive polyhedra in four dimensions*, 2000. https://arxiv.org/abs/hep-th/0002240.

[135] M. Demirtas, L. McAllister and A. Rios-Tascon, *Bounding the kreuzer-skarke landscape*, 2020. https://arxiv.org/abs/2008.01730.

[136] A. Chandra, A. Constantin, K. Fraser-Taliente, T. R. Harvey and A. Lukas, *Enumerating calabi-yau manifolds: Placing bounds on the number of diffeomorphism classes in the kreuzer-skarke list*, 2023. https://arxiv.org/abs/2310.05909.

[137] J. Halverson, C. Long and B. Sung, *On algorithmic universality in f-theory compactifications*, 2017. https://doi.org/10.1103/PhysRevD.96.126006, https://arxiv.org/abs/1706.02299.

[138] W. Taylor and Y.-N. Wang, *Scanning the skeleton of the 4d f-theory landscape*, 2017. https://doi.org/10.1007/JHEP01(2018)111, https://arxiv.org/abs/1710.11235.

[139] M. Demirtas, C. Long, L. McAllister and M. Stillman, *The kreuzer-skarke axiverse*, 2018. https://arxiv.org/abs/1808.01282.

[140] S. V. P. Fallon, J. Halverson, L. McAllister and Y. Zhu, *F-theory axiverse*, 2025. https://arxiv.org/abs/2511.20458.

[141] R. Harvey and H. B. Lawson, *Calibrated geometries*, *Acta Mathematica* **148** (1982) 47 .

[142] J. Halverson and D. R. Morrison, *On gauge enhancement and singular limits in g_2 compactifications of m-theory*, 2016. https://doi.org/10.1007/JHEP04(2016)100, https://arxiv.org/abs/1507.05965.

[143] S. K. Donaldson, *Some numerical results in complex differential geometry*, 2005. https://arxiv.org/abs/math/0512625.

[144] M. R. Douglas, R. L. Karp, S. Lukic and R. Reinbacher, *Numerical calabi-yau metrics*, 2006. https://doi.org/10.1063/1.2888403, https://arxiv.org/abs/hep-th/0612075.

[145] M. Headrick and T. Wiseman, *Numerical ricci-flat metrics on k3*, 2006. https://doi.org/10.1088/0264-9381/22/23/002, https://arxiv.org/abs/hep-th/0506129.

[146] M. Headrick and A. Nassar, *Energy functionals for calabi-yau metrics*, 2010. https://arxiv.org/abs/0908.2635.

[147] G. Butbaia, D. M. Peña, J. Tan, P. Berglund, T. Hübsch, V. Jejjala et al., *Physical yukawa couplings in heterotic string compactifications*, 2024. https://doi.org/10.4310/ATMP.241119041341, https://arxiv.org/abs/2401.15078.

[148] P. Berglund, G. Butbaia, T. Hübsch, V. Jejjala, C. Mishra, D. M. Peña et al., *cymyc – calabi-yau metrics, yukawas, and curvature*, 2024. https://doi.org/10.1007/JHEP03(2025)028, https://arxiv.org/abs/2410.19728.

[149] C. Mishra and J. Tan, *Hermitian yang–mills connections on general vector bundles: geometry and physical yukawa couplings*, 2025. https://arxiv.org/abs/2512.10907.

[150] A. Ashmore, *Eigenvalues and eigenforms on calabi-yau threefolds*, 2023. https://doi.org/10.1016/j.geomphys.2023.105028, https://arxiv.org/abs/2011.13929.

[151] M. Larfors, A. Lukas, F. Ruehle and R. Schneider, *cymetric*, 2022. https://github.com/pythoncymetric/cymetric.

[152] J. Halverson and F. Ruehle, *Metric flows with neural networks*, 2024. https://doi.org/10.1088/2632-2153/ad8533, https://arxiv.org/abs/2310.19870.

[153] R. S. Sutton and A. G. Barto, *Reinforcement learning: an introduction*, Adaptive computation and machine learning series. The MIT Press, Cambridge, Massachusetts, second edition ed., 2018.

[154] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare et al., *Human-level control through deep reinforcement learning*, *Nature* **518** (2015) 529.

[155] J. Schulman, S. Levine, P. Moritz, M. I. Jordan and P. Abbeel, *Trust region policy optimization*, 2017. https://arxiv.org/abs/1502.05477.

[156] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. P. Lillicrap, T. Harley et al., *Asynchronous methods for deep reinforcement learning*, 2016. https://arxiv.org/abs/1602.01783.

[157] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez et al., *Mastering the game of go without human knowledge*, *Nature* **550** (2017) 354.

[158] D. Silver, T. Hubert, J. Schrittwieser, I. Antonoglou, M. Lai, A. Guez et al., *Mastering chess and shogi by self-play with a general reinforcement learning algorithm*, 2017. https://arxiv.org/abs/1712.01815.

[159] R. Blumenhagen, M. Cvetic, P. Langacker and G. Shiu, *Toward realistic intersecting d-brane models*, 2005. https://doi.org/10.1146/annurev.nucl.55.090704.151541, https://arxiv.org/abs/hep-th/0502005.

[160] C. Manolescu and L. Piccirillo, *From zero surgeries to candidates for exotic definite four-manifolds*, 2023. https://arxiv.org/abs/2102.04391.

[161] M. Bies, M. Cvetic, R. Donagi, L. Lin, M. Liu and F. Ruehle, *Machine learning and algebraic approaches towards complete matter spectra in 4d f-theory*, 2020. https://doi.org/10.1007/JHEP01(2021)196, https://arxiv.org/abs/2007.00009.

[162] A. Davies, A. Juhász, M. Lackenby and N. Tomasev, *The signature and cusp geometry of hyperbolic knots*, 2022. https://doi.org/10.2140/gt.2024.28.2313, https://arxiv.org/abs/2111.15323.

[163] P. Ginsparg, *Applied conformal field theory*, 1988. https://arxiv.org/abs/hep-th/9108028.