

扩散模型原理

The Principles of Diffusion Models

Chieh-Hsin Lai　Yang Song　Dongjun Kim
Yuki Mitsufuji　Stefano Ermon

冻结源范围译稿 · 审校交付候选

审校范围及记录见交付说明；待主控验收

arXiv:2510.21890v3（2026）· MIT Press 即将出版（2027）
Model: gpt-6.1-sol（本轮；早期记录未确认）
审核：曹溪能
Updated: 2026-11-06

目录

作者信息与摘要 **9**

致谢 **11**

序言与阅读路线 **13**

记号 **19**

第一部分　深度生成建模导论 **23**

第一章　深度生成建模 **25**

1.1　什么是深度生成建模? 25

1.1.1　数学设定 26

1.1.2　分布建模面临的挑战 28

1.2　主要的深度生成模型 29

1.3　建模的分类 33

1.4　结束语 33

第二部分　扩散模型的基础与视角 **35**

第二章　变分视角：从 VAE 到 DDPM **43**

2.1　变分自编码器 43

2.1.1　概率编码器与解码器 44

2.1.2　通过证据下界（ELBO）训练 44

2.1.3　高斯 VAE 46

2.1.4　标准 VAE 的缺点 46

2.1.5　（可选）从标准 VAE 到层次 VAE 47

2.2　变分视角：DDPM 49

2.2.1　正向过程（固定编码器） 50

2.2.2　反向去噪过程（可学习解码器） 51

2.2.3　反向转移核 $p_\phi(x_{i-1} \mid x_i)$ 的建模 53

2.2.4　预测与损失的实际选择 54

2.2.5 DDPM 的 ELBO 55
2.2.6 采样 57
2.3 结束语 59

第三章 得分视角：从 EBM 到 NCSN **61**
3.1 基于能量的模型 61
3.1.1 用能量函数建模概率分布 61
3.1.2 动机：什么是得分? 62
3.1.3 通过得分匹配训练 EBM 63
3.1.4 使用得分函数的 Langevin 采样 64
3.2 从基于能量到基于得分的生成模型 66
3.2.1 用得分匹配训练 66
3.2.2 用 Langevin 动力学采样 67
3.2.3 序曲：基于得分的生成模型 68
3.3 去噪得分匹配 68
3.3.1 动机 68
3.3.2 训练 68
3.3.3 采样 70
3.3.4 为什么 DSM 是去噪：Tweedie 公式 71
3.3.5 （可选）为什么 DSM 是去噪：SURE 72
3.3.6 （可选）广义得分匹配 73
3.4 多噪声水平的去噪得分匹配（NCSN） 74
3.4.1 动机 74
3.4.2 训练 75
3.4.3 采样 77
3.5 总结：NCSN 与 DDPM 的比较 78
3.6 结束语 78

第四章 当代扩散模型：得分 SDE 框架 **81**
4.1 得分 SDE 的原理 82
4.1.1 动机：从离散到连续时间过程 82
4.1.2 正向时间 SDE：从数据到噪声 84
4.1.3 用于生成的逆时间随机过程 85
4.1.4 用于生成的确定性过程（概率流 ODE） 87
4.2 正逆时间 SDE 与 PF-ODE 的边缘匹配 87
4.2.1 用 Fokker–Planck 方程保证边缘密度对齐 87
4.2.2 可计算的例子：高斯动力学的演化 90
4.3 得分 SDE 的训练与采样 92
4.3.1 训练 92
4.3.2 采样与推断 93

4.4 SDE 的具体实例 . . . 95
4.4.1 VE SDE . . . 95
4.4.2 VP SDE . . . 96
4.4.3 （可选）如何导出扰动核? . . . 96
4.5 通过累积扰动核直接理解扩散 . . . 97
4.5.1 与得分 SDE 的联系 . . . 98
4.5.2 与变分扩散模型的联系 . . . 99
4.6 （可选）通过边缘化与 Bayes 规则理解 Fokker–Planck 方程和逆时间 SDE . . . 100
4.6.1 从转移核边缘化得到 Fokker–Planck 方程 . . . 101
4.6.2 逆时间 SDE 为什么具有这一形式? . . . 101
4.7 结束语 . . . 103

第五章 流视角：从归一化流到流匹配 105
5.1 流模型：归一化流与神经 ODE . . . 106
5.1.1 归一化流 . . . 106
5.1.2 神经 ODE . . . 108
5.2 流匹配框架 . . . 111
5.2.1 从得分方法得到的启示 . . . 111
5.2.2 流匹配框架 . . . 113
5.2.3 扩散模型、一般流匹配与 NODE 的比较 . . . 116
5.2.4 （可选）底层规则 . . . 116
5.3 构造分布间的概率路径与速度 . . . 118
5.3.1 关键特例：高斯到高斯桥的边缘与速度 . . . 118
5.3.2 先指定条件概率路径的构造 . . . 119
5.3.3 先指定条件流的构造 . . . 121
5.3.4 先指定概率路径与先指定流的比较 . . . 123
5.3.5 条件路径笔直不意味着边缘流笔直 . . . 123
5.4 （可选）典范仿射流的性质 . . . 125
5.4.1 流的整流：从带噪猜测到有结构的配对 . . . 125
5.4.2 Reflow：迭代拉直流 . . . 126
5.4.3 Reflow 的性质 . . . 127
5.5 结束语 . . . 128

第六章 统一而系统的扩散模型视角 129
6.1 条件化技巧：扩散模型的秘诀 . . . 130
6.2 理清扩散模型训练损失的路线图 . . . 133
6.2.1 四种常见参数化 . . . 133
6.2.2 拆解扩散模型的训练目标 . . . 134
6.3 扩散模型中的等价 . . . 137
6.3.1 四种预测类型等价 . . . 137

6.3.2 不同参数化下的 PF-ODE . . . 138
6.3.3 所有仿射流都等价 . . . 139
6.3.4 （可选）参数化与规范流的分析 . . . 142
6.4 共同基础：Fokker–Planck 方程 . . . 144
6.4.1 流方法与得分 SDE 的联系 . . . 146
6.5 结束语 . . . 148

第七章 （可选）扩散模型与最优传输 149
7.1 分布到分布转换的序幕 . . . 149
7.2 问题设定的分类 . . . 150
7.2.1 最优传输（OT） . . . 150
7.2.2 熵正则最优传输（EOT） . . . 152
7.2.3 Schrödinger 桥（SB） . . . 154
7.2.4 全局推前与局部动力学：DGM 的 OT 类比 . . . 157
7.3 不同最优传输表述的关系 . . . 158
7.3.1 SB 与 EOT 的（对偶）等价 . . . 158
7.3.2 $\varepsilon \to 0$ 时 EOT 约化为 OT . . . 160
7.3.3 $\varepsilon \to 0$ 时 SB 约化为 OT . . . 161
7.4 扩散 SDE 是 SB 问题的最优解吗? . . . 161
7.4.1 扩散模型作为 Schrödinger 桥的特例 . . . 161
7.4.2 扩散模型作为 Schrödinger 半桥 . . . 162
7.5 扩散模型的 ODE 是 OT 问题的最优映射吗? . . . 163
7.5.1 PF-ODE 流通常不是最优传输 . . . 163
7.5.2 典范线性流和 Reflow 能得到 OT 映射吗? . . . 167
7.6 结束语 . . . 169

C 部：扩散模型的采样 171

第八章 引导与可控生成 175
8.1 序幕 . . . 175
8.2 分类器引导 . . . 178
8.2.1 分类器引导的基础 . . . 178
8.2.2 使用 CG 推断 . . . 179
8.2.3 优点与局限 . . . 179
8.3 无分类器引导 . . . 180
8.3.1 无分类器引导的基础 . . . 180
8.3.2 CFG 的训练与采样 . . . 180
8.4 免训练引导 . . . 181
8.4.1 免训练引导的概念框架 . . . 182
8.4.2 引导采样产生什么分布? . . . 183

8.4.3 逆问题中免训练方法的例子 . . . 184
8.5 从强化学习到用于模型对齐的直接偏好优化 . . . 186
8.5.1 动机：绕开 RLHF 的困难 . . . 187
8.5.2 RLHF：Bradley–Terry 视角 . . . 187
8.5.3 DPO 框架 . . . 188
8.5.4 Diffusion-DPO . . . 189
8.6 结束语 . . . 192

第九章 用于快速扩散采样的数值求解器 193
9.1 序幕 . . . 193
9.1.1 快速采样作为数值积分 . . . 193
9.1.2 扩散专用求解器的设计 . . . 195
9.1.3 从数值思想到扩散采样器的路线图 . . . 197
9.2 DDIM . . . 197
9.2.1 DDIM 作为一阶扩散求解器 . . . 198
9.2.2 与 Euler 类方法的关系 . . . 200
9.2.3 （可选）DDIM 最初的变分视角 . . . 203
9.3 DEIS . . . 205
9.3.1 背景：多项式外推 . . . 206
9.3.2 DEIS：PF-ODE 积分的 Lagrange 多项式近似 . . . 206
9.3.3 DDIM = AB-DEIS-0 . . . 208
9.4 DPM-Solver . . . 209
9.4.1 DPM-Solver 的洞见：以对数 SNR 重参数化时间 . . . 209
9.4.2 以 Taylor 展开估计积分 . . . 211
9.4.3 DPM-Solver-n 的实现 . . . 211
9.4.4 DDIM = DPM-Solver-1 . . . 213
9.4.5 DPM-Solver 与 Runge–Kutta 类求解器的关系 . . . 213
9.5 DPM-Solver++ . . . 214
9.5.1 从 DPM-Solver 到用于引导采样的 DPM-Solver++ . . . 214
9.5.2 DPM-Solver++ 的方法 . . . 215
9.5.3 通过 Taylor 展开构造单步法 . . . 215
9.5.4 通过复用历史构造多步法 . . . 216
9.5.5 DPM-Solver++(2M) 与 DEIS 的关系 . . . 217
9.5.6 结束评论 . . . 218
9.6 （可选）ParaDiGMs . . . 219
9.6.1 从时间步进到时间并行求解器 . . . 219
9.6.2 ParaDiGMS 的方法 . . . 219
9.6.3 与时间步进求解器的关系 . . . 221
9.7 结束语 . . . 223

D 部：走向快速扩散生成器的学习 **225**

第十章 用于快速采样的蒸馏方法 **227**

10.1 序幕 . . . 227
10.1.1 分布层面蒸馏 . . . 228
10.1.2 流映射层面蒸馏 . . . 228
10.2 基于分布的蒸馏 . . . 229
10.2.1 以 VSD 为代表的表述 . . . 229
10.2.2 VSD 的训练流程 . . . 230
10.2.3 KL 之外：一般散度及 KL 的特殊性 . . . 231
10.3 渐进蒸馏 . . . 231
10.3.1 PD 中的蒸馏操作 . . . 232
10.3.2 PD 完整训练流程及采样 . . . 233
10.3.3 补充讨论：局部半群匹配及推广求解器的可能 . . . 233
10.3.4 含引导的 PD . . . 234
10.4 结束语 . . . 234

第十一章 从头学习快速生成器 **235**

11.1 序幕 . . . 235
11.2 特殊流映射：离散时间一致性模型 . . . 237
11.2.1 学习一致性函数的离散时间近似 . . . 238
11.2.2 一致性模型的采样 . . . 240
11.3 特殊流映射：连续时间一致性模型 . . . 241
11.3.1 连续时间一致性模型 . . . 241
11.3.2 训练连续时间一致性模型 . . . 242
11.3.3 （可选）连续时间 CT 的实践考虑 . . . 243
11.4 一般流映射：一致性轨迹模型 . . . 245
11.4.1 用于灵活转移学习的 CTM 参数化 . . . 246
11.4.2 CTM 的一致性损失 . . . 246
11.4.3 CTM 的辅助损失 . . . 247
11.4.4 CTM 的灵活采样 . . . 248
11.5 一般流映射：Mean Flow . . . 250
11.5.1 Mean Flow 的建模与训练 . . . 250
11.5.2 Mean Flow 的采样 . . . 251
11.5.3 CTM 与 MF 的关系 . . . 251
11.6 结束语 . . . 253

尾声与展望 **257**

第十二章 统一原理与未来之路 **259**

12.1 密度输运的骨架 . . . 259
12.2 超越连续状态：离散空间上的概率演化 . . . 261
12.2.1 离散时间转移 . . . 262
12.2.2 连续时间极限：主方程 . . . 265
12.2.3 逆向建模的三种视角 . . . 267
12.2.4 哪些相似，哪些有实质差别？ . . . 271
12.3 全书结束语 . . . 272

附录 275

附录 A 微分方程速成 277
A.1 常微分方程基础 . . . 277
A.1.1 常微分方程的直观理解 . . . 277
A.1.2 常微分方程的存在与唯一性 . . . 278
A.1.3 指数积分因子 . . . 280
A.1.4 常微分方程的数值求解器 . . . 281
A.1.5 代表性数值求解器 . . . 282
A.2 随机微分方程基础 . . . 283
A.2.1 从 ODE 到 SDE：直观引入 . . . 283
A.2.2 进一步解释 SDE 式 . . . 284
A.2.3 SDE 的一种数值求解器 . . . 285

附录 B 密度演化：从变量变换到 Fokker–Planck 287
B.1 变量变换公式：从确定性映射到随机流 . . . 287
B.1.1 确定性映射的变量变换公式 . . . 287
B.1.2 连续时间极限：连续性方程 . . . 289
B.1.3 随机过程：Fokker–Planck 方程 . . . 291
B.2 连续性方程的直觉 . . . 291
B.2.1 连续性方程的物理解释 . . . 292
B.2.2 从守恒律推导连续性方程 . . . 292
B.3 （可选）以 Wasserstein 梯度流理解分布层面的训练 . . . 293

附录 C 扩散模型的幕后：Itô 微积分与 Girsanov 定理 297
C.1 Itô 公式：随机过程的链式法则 . . . 297
C.1.1 动机：为何需要特殊链式法则？ . . . 298
C.1.2 由 Taylor 展开推导一维 Itô 公式 . . . 298
C.1.3 Itô 公式：SDE 的链式法则 . . . 299
C.1.4 应用：推导 Fokker–Planck 方程 . . . 300
C.1.5 应用：线性 SDE 的闭式解 . . . 300
C.2 测度的变量变换：扩散模型中的 Girsanov 定理 . . . 302

C.2.1 Girsanov 定理：连接似然训练与得分匹配 302

附录 D 补充材料与证明 **305**

D.1 变分视角 305
D.1.1 定理 2.2.1：边缘与条件 KL 最小化的等价性 305
D.1.2 定理 2.2.3：扩散模型的 ELBO 306
D.2 得分视角 307
D.2.1 命题 3.2.1：通过积分分部得到可解得分匹配 307
D.2.2 定理 3.3.1：SM 与 DSM 最小化等价 307
D.2.3 引理 3.3.2：Tweedie 公式 308
D.2.4 Stein 恒等式与 SURE 替代目标 309
D.2.5 定理 4.2.1：通过 Fokker–Planck 对齐边缘 310
D.2.6 命题 4.3.1：SM 与 DSM 的最小化解 311
D.2.7 Gaussian 得分的闭式公式 311
D.3 流视角 312
D.3.1 引理 5.1.1：瞬时变量变换 312
D.3.2 定理 5.2.2：质量守恒判据 312
D.4 理论补充：统一且系统的扩散模型视角 313
D.4.1 命题 6.3.1：参数化的等价性 313
D.5 理论补充：学习快速扩散式生成器 314
D.5.1 知识蒸馏损失是原式 (10.1.4) 一般框架的实例 314
D.5.2 定理 11.2.1：CM 与 CT 相差至多二阶小量 314
D.5.3 命题 11.3.1：CT 梯度的连续时间极限 315
D.6 （可选）阐明扩散模型（EDM） 316
D.6.1 神经网络干净预测器的设计准则 316
D.6.2 常见 EDM 特例：单位信号系数、线性噪声尺度 317

参考文献 **319**

作者信息与摘要

扩散模型原理

Chieh-Hsin Lai[1]、Yang Song[2]、Dongjun Kim[3]、Yuki Mitsufuji[4]、Stefano Ermon[5]

1. Sony AI；chieh-hsin.lai@sony.com / chiehhsinlai@gmail.com。

2. OpenAI[1]；thusongyang@gmail.com。

3. Stanford University；dongjun@stanford.edu。

4. Sony Group Corporation、Sony AI；yuhki.mitsufuji@sony.com。

5. Stanford University；ermon@cs.stanford.edu。

摘要

本书聚焦塑造扩散模型发展的基本原理，追溯其起源，说明不同表述如何产生于共同的数学思想。

扩散建模首先指定一个正向扰动过程，将数据逐渐变为噪声。该过程定义一族连续的中间分布，从而连接数据分布与简单噪声分布。扩散模型的核心目标是构造另一个反向运行的过程，在将噪声转为数据的同时，恢复由正向扰动过程定义的同一族中间分布。

我们介绍将这一思想形式化的三种互补方式。受变分自编码器启发的变分视角，将扩散视为学习逐步去噪：求解一系列小的去噪目标，共同教会模型将噪声还原为数据。根植于能量建模的得分视角，学习演化中数据分布的梯度，指示如何将样本推向更可能的区域。与归一化流相关的流视角，把生成看作在学得速度场作用下，沿平滑路径将样本从噪声移动到数据。

这些视角有共同的骨架：一个学得的时变速度场，其流将简单先验输运到数据。有了这一骨架，采样就是求解微分方程，沿连续生成轨迹将噪声演化为数据。在此基础上，本书讨论可控生成的引导、高效采样的先进数值求解器，以及受扩散启发、学习该轨迹上任意时刻之间直接映射的流映射模型。

本书面向具有深度学习基础、希望清楚地从概念和数学层面理解扩散模型的读者。我们阐述其核心原理，解释统一各种表述的思想，为进一步研究这一快速发展的领域提供坚实基础。因此，本书既可作为研究者的原理性参考，也可作为学生和初学者易于入门的读物。补充材料见本书网站：`https://the-principles-of-diffusion-models.github.io/`。

[1]隶属机构反映开展本项工作时的任职机构。

致谢

我们衷心感谢社区中许多提供宝贵反馈、帮助我们发现勘误的成员。特别感谢以下人士，按字母顺序列出：Francis Bach、Ilia Badanin、Rwiddhi Chakraborty、Mauricio Delbracio、Jacob Lessing、Kaiming He、Yutong (Kelly) He、Durk Kingma、Shucheng Li、Ramtin Moslemi、Rukmangadh Sai Myana、Stefano Peluchetti、Yuri Plotkin、François Rozet、Yair Shenfeld、Molei Tao、Mohamad Ternanni、Baojian Zhou，以及匿名审稿人和其他慷慨分享意见的读者。

作者还深切感谢首尔市立大学和韩国高等科学院（KIAS）的 Dohyun Kwon 教授为本书投入的大量时间与精力。他仔细审阅了第 7 章的部分内容，帮助确保陈述和证明的正确性，并参与了多次有益讨论，使表述更加清楚。除技术建议外，他周到的反馈和乐于分享见解的精神，也在本书写作过程中给了我们鼓励。我们诚挚感谢他的支持和同事情谊，这些都丰富了最终版本。

序言与阅读路线

扩散模型已迅速成为生成建模的核心范式之一，相关研究遍及机器学习、计算机视觉、自然语言处理等领域。这些文献分散在不同社区，关注进展的不同方面：理论基础涉及建模原理、训练目标、采样器设计及其背后的数学思想；实现进展涵盖工程实践与架构选择；实际应用将模型适配到特定领域或任务；系统级优化则提高计算、内存和部署效率。

本书旨在为扩散模型建立原理性基础，聚焦以下核心主题：

- 介绍支撑扩散模型研究的基本概念和表述，帮助读者获得阅读更广泛文献所需的核心理解。我们不综述全部变体或领域应用，而是建立可用于理解这些发展的稳定概念基础。
- 经典生成模型学习从噪声到数据的直接映射，扩散模型则将生成视为随时间逐渐发生的变换，从粗结构细化到精细细节。这一核心思想主要沿变分、得分和流三种视角发展，提供了理解和实现扩散建模的互补方式。我们关注这些表述的核心原理和基础，追溯关键思想的起源，澄清不同表述的关系，形成连接直观认识与严谨数学表述的连贯理解。
- 在这些基础上，考察如何进一步发展扩散模型，使生成更高效、生成过程更可控，并启发建立在扩散原理上的独立生成建模形式。

本书面向具备深度学习基本知识（例如知道神经网络是什么、训练如何进行），或更具体地具备深度生成建模基础，并希望深入理解扩散模型的研究者、研究生和实践者。读完后，读者将从原理上理解扩散建模的基础，能够在统一框架中解释不同表述，并具备自信应用现有模型和探索新研究方向所需的背景。

本书阅读路线

本书系统介绍扩散模型的基础，追溯其背后的核心原理。

建议阅读顺序。 建议按书中次序阅读，建立全面理解。标为“可选”的部分可由已熟悉基础的读者略过。例如，熟悉深度生成模型（DGM）的读者可跳过第 一章概览。类似地，已有变分自编码器（第 2.1 节）、能量模型（第 3.1 节）或归一化流（第 5.1 节）知识的读者，可略过相应导论。其他可选部分深入讨论高级或专门主题，可按需查阅。本书分为四个主要部分。

A、B 部：扩散模型的基础。 这一部分回顾塑造该领域的三种基础视角，追溯扩散模型的起源。[2]图 3 给出这一部分的概览。

[2]我们按三种视角组织扩散模型，是概念性的安排，而非时间顺序。例如，能量方法有更悠久的历史。统计力学将概率与能量联系起来，布朗运动及后续研究描述了概率分布如何随时间演化（原引文键：gibbs1902elementary;

A 部：深度生成建模导论。 第一章首先回顾深度生成建模的基本目标。从一组数据样本出发，目标是建立一个模型，使其产生看起来来自同一个、通常未知的底层数据分布的新样本。许多方法显式使用概率模型，或隐式使用学得变换，学习数据如何分布。随后说明这些模型如何用神经网络表示数据分布、如何从样本学习，以及如何生成新样本。章末分类介绍主要生成框架，突出其核心思想和关键区别。

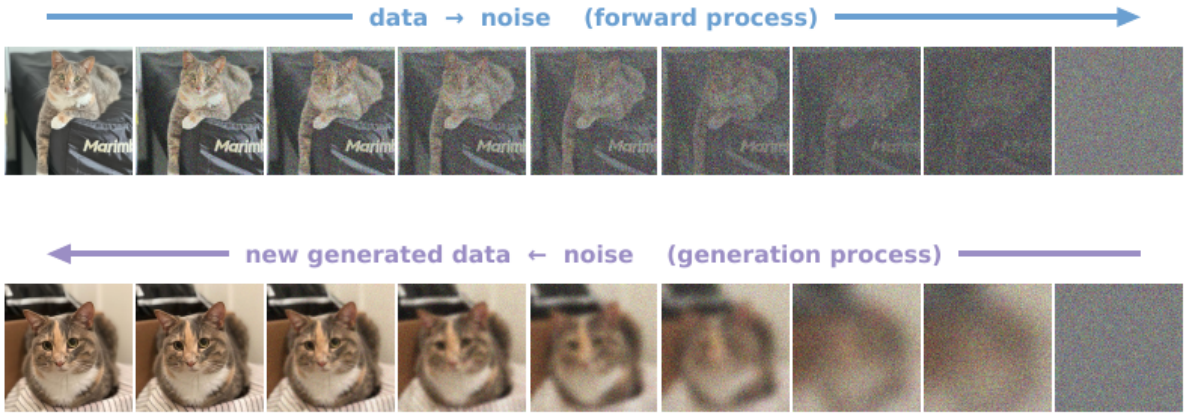


图 1: 正向和反向扩散轨迹。正向过程（上）逐渐用噪声扰动真实数据样本，经过一系列中间含噪阶段，直至与纯噪声无法区分。反向过程（下）从新噪声出发，逐渐去噪，产生新图像。反向过程并非重建训练中见过的某个特定样本，而是从新噪声出发，逐步塑造逼真的新样本。图内上行为数据 → 噪声（正向过程），下行为新生成数据 ← 噪声（生成过程）。来源：作者绘制。

B 部：扩散模型的核心视角。 在概述深度生成建模的一般目标和机制后，我们转向扩散模型：通过从噪声到数据的逐渐变换实现生成（图 1）。核心思想很简单：不断向数据样本加入噪声，直至与纯随机性无法区分。正向过程把不同数据样本移到同一个简单噪声空间，该空间易于采样，因而成为生成的起点。过程中还构造了连接数据和噪声的平滑中间含噪阶段序列。生成时，从这个空间抽取新噪声，通过逆时间（生成）过程逐渐去噪，最终得到新数据样本。这一过程不恢复某个特定原始样本，而是从新噪声出发，逐渐将其变成逼真数据。我们研究三个互相关联的框架，它们均建立在同一个原则上：正向过程逐渐加噪，逆时间过程则由逐步去噪的一系列模型近似。

- **变分视角（第 2 章）：**起源于变分自编码器（VAE；Kingma and Welling, 2013），以变分目标学习去噪过程，产生去噪扩散概率模型（DDPM；Sohl-Dickstein et al., 2015; Ho et al., 2020）。

- **得分视角（第 3 章）：**根植于能量模型（EBM；Ackley et al., 1985），发展为噪声条件得分网络（NCSN；Song and Ermon, 2019）。它学习得分函数，即对数数据密度的梯度，指引如何逐步去噪。第 4 章在连续时间下引入 Score SDE 框架，用随机微分方程（SDE）及

`langevin1908brownian; fokker1914mittlere; planck1917satz; kolmogorov1931`）。现代扩散概率模型后来将相关思想引入生成建模，并明确受到非平衡统计物理启发（Sohl-Dickstein et al., 2015）。因此，这三种视角应理解为解释扩散模型的现代方式，而非其底层思想起源的严格历史排序。原文显示为键的引文按源保留，不能据此补造缺失书目。

其确定性对应物常微分方程（ODE）描述去噪。这将扩散建模与经典微分方程理论联系起来，为分析与算法设计提供清楚的数学基础。

- **流视角（第 5 章）：**建立于归一化流（Rezende and Mohamed, 2015），并由流匹配（Lipman et al., 2022）推广，把生成建模为从简单先验向数据分布输运样本的连续变换。演化由 ODE 中的速度场控制，明确描述概率质量如何随时间移动。这一表述自然从先验到数据的生成，扩展到更一般的分布间转换：学习连接任意一对源分布和目标分布的流。

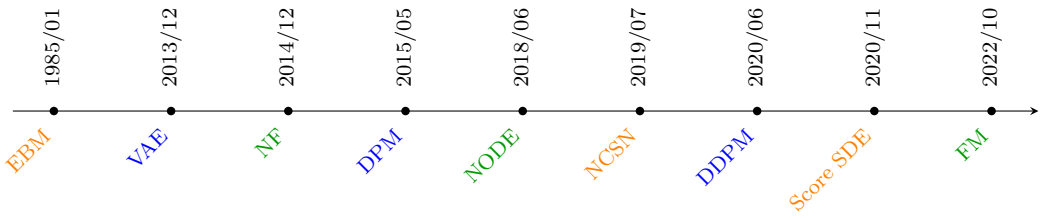


图 2: 现代机器学习视角下扩散模型的发展时间线；同一组使用相同颜色。第 2 章：VAE（Kingma and Welling, 2013）→DPM（Sohl-Dickstein et al., 2015）→DDPM（Ho et al., 2020）。第 3、4 章：EBM（Ackley et al., 1985）→NCSN（Song and Ermon, 2019）→Score SDE（Song et al., 2020c）。第 5 章：NF（Rezende and Mohamed, 2015）→NODE（Chen et al., 2018）→FM（Lipman et al., 2022）。时间点按原图保留，表示图中所用文献的现代发展脉络。来源：作者绘制；本译稿以可编辑 TikZ 保留九个节点、时间及分组。

这些视角起初看似不同，但第 6 章说明它们紧密相连。每种视角均使用条件化策略，把学习目标变成可解的回归问题。更深一层，它们描述同一个从先验走向数据的概率分布时间演化。演化由 Fokker–Planck 方程控制，可将其看作密度的连续时间变量变换，确保随机表述与确定性表述的一致性。

由于扩散模型可视为将一个分布输运到另一个分布的方法，第 7 章讨论其与经典最优传输和薛定谔桥的关系；后者可解释为带熵正则的最优传输。我们回顾静态、动态表述及其与连续性方程、Fokker–Planck 视角的关系。关注实践的读者可略过本章；希望深入研究这些联系的读者，则可从中获得严谨数学背景和经典文献线索。

C、D 部：控制并加速扩散采样。 在统一基础原理后，我们转向利用扩散模型高效生成的实践问题。扩散采样对应于求解微分方程，但这一过程通常计算昂贵。C、D 部通过改进采样和学习加速技术，提高生成质量、可控性和效率。

C 部：扩散模型的采样。 扩散生成具有独特的从粗到细的细化过程：逐步去噪，使样本的结构和细节越来越连贯。这带来权衡。一方面，它允许精细控制：向学得的时变速度场加入引导项，就能使 ODE 流反映用户意图，实现可控采样。另一方面，迭代积分使其比一次生成的模型更慢。本部关注在推断时改进生成过程，无需重训。

- **引导生成（第 8 章）：**分类器引导和无分类器引导等技术，能按用户指定目标或属性进行条件生成。在此基础上，进一步讨论使用偏好数据集，使扩散模型与这些偏好更好地对齐。

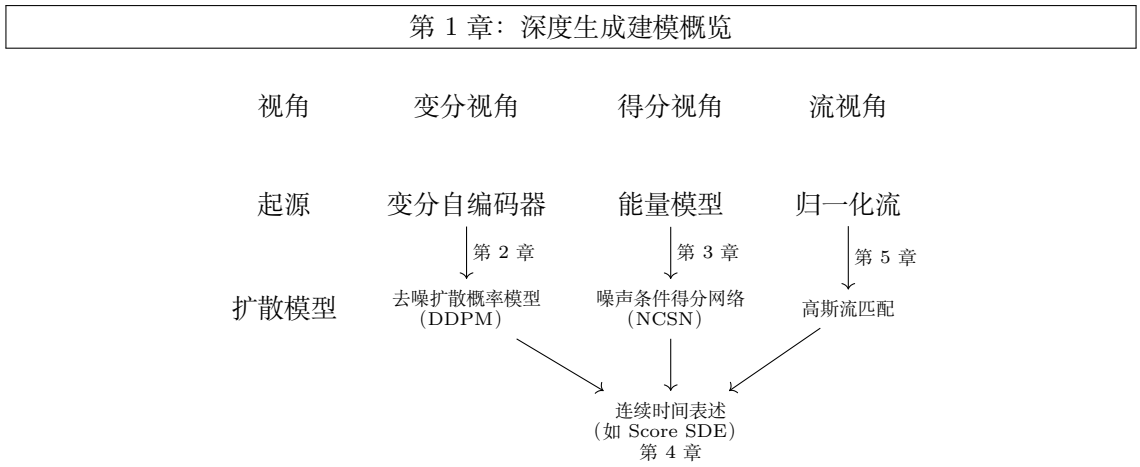


图 3: B 部：统一且立足原理的扩散模型视角。图中把经典生成方法——变分自编码器、能量模型、归一化流——与对应扩散模型表述联系起来。各纵向路径表示概念谱系，最终汇入连续时间框架。变分、得分、流三种视角给出不同但数学上等价的解释。来源：作者绘制；六条箭头由可编辑 tikzcd 保留。

- **用数值求解器快速生成（第 9 章）：**先进数值求解器用更少步骤近似逆过程，在保持质量的同时降低成本，从而显著加速采样。

D 部：学习快速生成模型。 除改进现有采样算法外，我们还研究如何直接学习近似扩散过程的快速生成器。

- **基于蒸馏的方法（第 10 章）：**训练学生模型模仿预训练的慢扩散模型（教师）。目标是以更少积分步骤，通常几步甚至一步，复现教师的采样轨迹或输出分布，而非缩小教师规模。
- **从头学习（第 11 章）：**既然扩散采样可看作求解 ODE，这种方法便不依赖教师模型，直接从头学习解映射（即流映射）。学得映射可将噪声直接变为数据，更一般地可沿解轨迹进行任意时刻之间的跳转。

尾声：超越连续状态空间上的扩散。 第 12 章明确贯穿全书的原理：扩散建模的核心并不依赖某一种噪声、模型类别，甚至不依赖连续状态空间；它研究的是概率质量如何在指定时变正向扰动过程下演化，以及如何将这种演化反转、近似或用于生成。在连续情形中，这一原理体现为变量变换公式、连续性方程和 Fokker–Planck 方程；在离散情形中，转移核、连续时间 Markov 链和主方程发挥同样的结构作用。

末章还说明，全书发展的变分、得分和流三种视角可超越连续数据建模。即使对文本、蛋白质序列和其他 token 对象等离散数据，也可通过变分目标、类似得分的比值或逆速率刻画，以及类似流的输运视角，建立逆向模型。数学对象发生改变，底层原理则保持不变。因此，尾声既是全书概念上的归结，也展望更广阔的生成建模领域。

附录。 为使读者顺利跟上讨论，附录补充基础概念。附录 A 速讲微分方程这一扩散模型的语言。尽管扩散模型的视角与起源多样，其核心认识在于变量变换公式。这一基础自然延伸到

Fokker–Planck 方程和连续性方程，描述概率密度在函数（离散时间）或微分方程（连续时间）定义的映射下如何变换、演化。附录 B 平缓地连接这些基础与较高级概念。附录 C 介绍扩散模型背后两种有力却常被忽略的工具：Itô 公式与 Girsanov 定理，它们为 Fokker–Planck 方程和逆时间采样提供严谨支撑。最后，附录 D 收集正文中部分命题和定理的证明。

本书涉及与不涉及的内容。 我们着眼于经得起时间检验的内容。从自上而下的角度，本书由一个原理出发：构造将简单先验输运到数据分布的连续时间动力学，同时确保每个时刻的边缘分布，与指定的数据到噪声正向过程诱导的边缘相同。由此发展用于采样的随机流和确定性流，说明如何引导轨迹、如何用数值求解器加速；随后研究受扩散启发的快速生成器，包括蒸馏方法和流映射模型。借助这些工具，读者可以把新论文放进共同模板，理解方法为何有效，并设计改进模型。

我们不打算穷尽扩散文献，也不罗列架构、训练实践或超参数，不比较方法的经验结果，不介绍数据集和排行榜，不讨论领域或模态特定应用、系统级部署、大规模训练配方或硬件工程。这些主题变化迅速，更适合由专门综述、开放代码库和实现指南介绍。

记号

数与数组

a	标量。
$\mathbf{a}$	列向量，例如 $\mathbf{a} \in \mathbb{R}^D$。
$\mathbf{A}$	矩阵，例如 $\mathbf{A} \in \mathbb{R}^{m \times n}$。
$\mathbf{A}^\top$	$\mathbf{A}$ 的转置。
$\mathrm{Tr}(\mathbf{A})$	$\mathbf{A}$ 的迹。
$\mathbf{I}_D$	$D \times D$ 单位矩阵。
$\mathbf{I}$	单位矩阵，维数由上下文确定。
$\mathrm{diag}(\mathbf{a})$	以 $\mathbf{a}$ 为对角元的对角矩阵。
ϕ, θ	可学习的神经网络参数。
$\phi^\times, \theta^\times$	训练后参数，推断时固定。
ϕ^*, θ^*	优化问题的最优参数。

微积分

$\partial \mathbf{y} / \partial \mathbf{x}$	$\mathbf{y}$ 对 $\mathbf{x}$ 的偏导数，按分量理解。
$d\mathbf{y}/d\mathbf{x}$ 或 $D\mathbf{y}(\mathbf{x})$	$\mathbf{y}$ 对 $\mathbf{x}$ 的全导数（Fréchet 导数）。
$\nabla_{\mathbf{x}} y$	标量 $y : \mathbb{R}^D \to \mathbb{R}$ 的梯度，为 $\mathbb{R}^D$ 中的列向量。
$\partial \mathbf{F} / \partial \mathbf{x}$ 或 $\nabla_{\mathbf{x}} \mathbf{F}$	$\mathbf{F} : \mathbb{R}^n \to \mathbb{R}^m$ 的 Jacobian，形状为 $m \times n$。
$\nabla \cdot \mathbf{y}$	向量场 $\mathbf{y} : \mathbb{R}^D \to \mathbb{R}^D$ 的散度，是标量。
$\nabla^2_{\mathbf{x}} f(\mathbf{x})$ 或 $H(f)(\mathbf{x})$	$f : \mathbb{R}^D \to \mathbb{R}$ 的 Hessian，形状为 $D \times D$。
$\int f(\mathbf{x})\, d\mathbf{x}$	在 $\mathbf{x}$ 的定义域上对 f 积分。

概率与信息论

$p(\mathbf{x})$	连续向量 $\mathbf{x}$ 上的密度或分布。
$\Pr(\mathbf{x} = \mathbf{a})$，或非正式地 $\Pr(\mathbf{x})$	离散情形的点概率。

$\Pr(\mathbf{x}=\mathbf{a}\mid\mathbf{y}=\mathbf{b})$，或非正式地 $\Pr(\mathbf{x}\mid\mathbf{y})$	离散情形的条件点概率。
p_{data}	数据分布。
p_{prior}	先验分布，例如标准正态。
p_{src}	源分布。
p_{tgt}	目标分布。
$\mathbf{a}\sim p$	随机向量 $\mathbf{a}$ 服从分布 p。
$\mathbb{E}_{\mathbf{x}\sim p}[f(\mathbf{x})]$	在 $p(\mathbf{x})$ 下 $f(\mathbf{x})$ 的期望。
$\mathbb{E}[f(\mathbf{x})\mid\mathbf{z}]$，或 $\mathbb{E}_{\mathbf{x}\sim p(\cdot\mid\mathbf{z})}[f(\mathbf{x})]$	给定 $\mathbf{z}$ 时 $f(\mathbf{x})$ 的条件期望，$\mathbf{x}$ 服从 $p(\cdot\mid\mathbf{z})$。
$\operatorname{Var}(f(\mathbf{x}))$	在 $p(\mathbf{x})$ 下的方差。
$\operatorname{Cov}(f(\mathbf{x}),g(\mathbf{x}))$	在 $p(\mathbf{x})$ 下的协方差。
$D_{\mathrm{KL}}(p\Vert q)$	从 q 到 p 的 Kullback–Leibler 散度（原文措辞）。[3]
$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$	标准正态样本。
$\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma})$	均值为 $\boldsymbol{\mu}$、协方差为 $\boldsymbol{\Sigma}$ 的 Gaussian 分布。

记号约定

以下汇总全书所用的若干约定。

1. **随机变量与其实现**。随机向量及其实现值使用同一个符号。这在深度学习和生成建模中很常见，可使记号紧凑；具体含义由上下文判断。对密度，$p(\mathbf{x})$ 表示分布的函数形式，而非在某个样本处的求值。若意在特定点求值，会明确说明。条件密度也按上下文理解：在 $p(\mathbf{x}\mid\mathbf{y})$ 中，固定 $\mathbf{y}$ 给出 $\mathbf{x}$ 的密度，固定 $\mathbf{x}$ 则给出 $\mathbf{y}$ 的函数。

2. **条件期望**。$\mathbb{E}[f(\mathbf{x})\mid\mathbf{z}]$ 表示 $\mathbf{z}$ 的函数，给出以 $\mathbf{z}$ 为条件的 $f(\mathbf{x})$ 期望。对某个特定实现值，写作 $\mathbb{E}[f(\mathbf{x})\mid\mathbf{Z}=\mathbf{z}]$。等价地，可对条件分布积分：

$$\mathbb{E}_{\mathbf{x}\sim p(\cdot\mid\mathbf{z})}[f(\mathbf{x})]=\int f(\mathbf{x})p(\mathbf{x}\mid\mathbf{z})\,d\mathbf{x}.$$

   这区分了把 $\mathbf{z}$ 视为定义 $\mathbf{z}\mapsto\mathbb{E}[f(\mathbf{x})\mid\mathbf{z}]$ 的变量，还是把它视为该函数取值处的固定点。

3. **隐含时间下标**。书中许多对象依赖时间，逐一写出时间变量会使公式繁重。若上下文清楚，就省略相关时间下标。例如，

$$\mathbb{E}[\mathbf{x}_s\mid\mathbf{x}_t]\quad\text{简写了}\quad\mathbb{E}[\mathbf{x}_s\mid\mathbf{x}_t,s,t],$$

   意为给定 t 时刻的 $\mathbf{x}_t$，对 s 时刻的 $\mathbf{x}_s$ 平均；s,t 由上下文理解。类似地，$p(\mathbf{x}_s\mid\mathbf{x}_t)$ 表示给定 $\mathbf{x}_t$ 时 $\mathbf{x}_s$ 的条件分布，两个时间下标均隐含。

4. **Gaussian 扰动与分布相等**。对固定 t，经常使用 Gaussian 扰动核

$$p_t(\mathbf{x}_t\mid\mathbf{x}_0)=\mathcal{N}(\mathbf{x}_t;\alpha_t\mathbf{x}_0,\sigma_t^2\mathbf{I}),$$

[3]译注：常见约定 $D_{\mathrm{KL}}(p\Vert q)=\int p\log(p/q)$ 亦称 p 相对于 q 的散度；原记号表的“from q to p”措辞按源保留，计算以全书公式定义为准。

其中 $\mathbf{x}_0 \sim p_{\text{data}}$，$\alpha_t, \sigma_t$ 为确定性标量。等价地，写成分布恒等式

$$\mathbf{x}_t \overset{d}{=} \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

其中 $\boldsymbol{\epsilon}$ 与 $\mathbf{x}_0$ 独立。$\overset{d}{=}$ 表示两边概率律相同，所以对任意检验函数 φ，

$$\mathbb{E}[\varphi(\mathbf{x}_t)] = \mathbb{E}[\varphi(\alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon})].$$

为简洁，全书直接写 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$，按上下文理解为分布相等，或一次样本实现。

第一部分

深度生成建模导论

第一章　深度生成建模

凡我不能创造的，我就不能理解。
Richard P. Feynman

深度生成模型（DGM）是学习高维数据（例如图像、文本和音频）上的概率分布、从而能够生成类似数据集中新样本的神经网络。我们以 p_ϕ 表示模型分布，以 p_{data} 表示数据分布。给定有限数据集，我们通过最小化衡量 p_ϕ 与 p_{data} 相距程度的损失来拟合 ϕ。训练后，生成就是运行模型的采样过程，抽取 $x \sim p_\phi$（是否能直接计算密度 $p_\phi(x)$ 取决于模型类别）。模型质量既由生成样本及其汇总统计量与 p_{data} 的匹配程度衡量，也由任务特定的或感知指标衡量。

本章构建这些思想背后的数学与概念基础。我们在第 1.1 节形式化问题，在第 1.2 节介绍具有代表性的模型类别，并在第 1.3 节总结实用的分类方法。

学完本章后，你将能够：

- 用通俗语言解释生成模型试图从数据集中学习什么，以及对数据分布建模意味着什么；
- 理解自回归模型、VAE、基于能量的模型、归一化流、GAN 和扩散模型的核心思想，并了解它们在学习和生成新样本方式上的区别。

阅读路线。　如果你已经熟悉现代生成模型的基本思想，可以略读本章，并在之后将其作为快速参考。

1.1　什么是深度生成建模？

DGM 以大量从未知复杂分布 p_{data} 抽取的真实世界样本（例如图像、文本）为输入，输出一个训练后的神经网络，其参数化了近似分布 p_ϕ。它有两个目标：

1. **逼真生成：**生成与真实数据无法区分的新颖、逼真样本。
2. **可控生成：**对生成过程进行细粒度且可解释的控制。

本节介绍 DGM 的基本概念与动机，为详细探索其数学框架和实际应用作准备。

1.1.1 数学设定

假设给定有限个样本 $\{x^{(i)}\}_{i=1}^{N}$，例如图像、音频或文本。我们设想这些样本是从某个底层数据分布 p_{data} 中抽取的，但并不显式知道该分布。特别地，我们只能观察到可用的训练样本；我们没有 p_{data} 的公式，也没有从中任意抽取新样本的直接过程。[1]

DGM 的目标。 因此，深度生成建模旨在学习一个模型，使其产生的样本在统计特征上类似于观测数据。我们以 p_ϕ 表示参数为 ϕ 的模型所表示的分布。训练后，以 $\phi^\times$ 表示学得的参数，希望在与生成相关的方面有

$$p_{\phi^\times} \approx p_{\text{data}}.$$

这一表达式应从概念上理解：由于数据有限、模型容量有限且优化不完美，我们不期待两个分布完全相同。相反，学习到的模型应捕捉到足够多的数据分布结构，以生成逼真而多样的新样本。

模型训练完成后，生成就意味着抽取新样本 $x \sim p_{\phi^\times}$。不同的生成模型家族提供不同的实现机制。有些模型还允许我们评估其赋予观测样本的密度，而另一些主要通过采样过程来定义。当我们之后讨论不同生成模型的训练方式时，这一区别会很有用；目前核心目标只是从数据中学习一个可以从中生成新样本的分布。

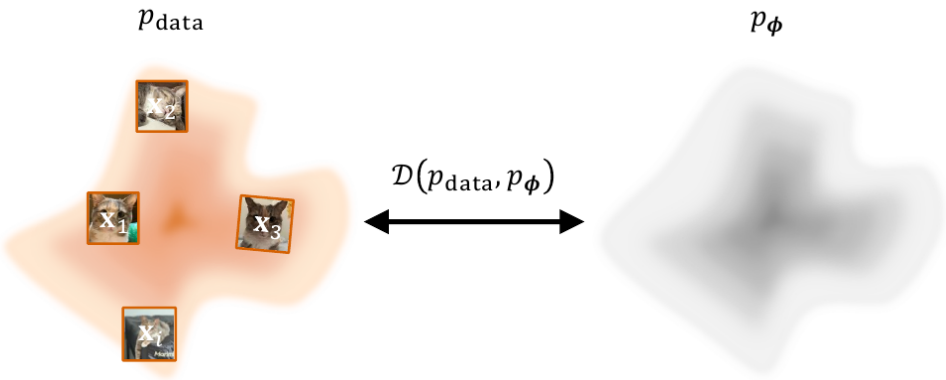


图 1.1: DGM 中目标的示意。训练 DGM 本质上是最小化模型分布 p_ϕ 与未知数据分布 p_{data} 之间的差异。由于 p_{data} 不能直接访问，必须利用从中抽取的有限个独立同分布 (i.i.d.) 样本 x_i 高效估计该差异。来源：作者绘制。

DGM 的训练。 我们通过最小化差异 $\mathcal{D}(p_{\text{data}}, p_\phi)$ 来学习模型族 $\{p_\phi\}$ 的参数 ϕ：

$$\phi^* \in \arg\min_{\phi} \mathcal{D}(p_{\text{data}}, p_\phi). \tag{1.1.1}$$

由于 p_{data} 未知，实用的 $\mathcal{D}$ 必须允许从 p_{data} 的独立同分布样本中高效估计。若模型容量足够，p_{ϕ^*} 可以紧密逼近 p_{data}。

[1] 这是机器学习中的常见假设。为简单起见，根据上下文，我们以符号 p 表示概率分布，或者其概率密度 / 质量函数。

正向 KL 与最大似然估计 (MLE)。 如何选择模型参数，使 p_ϕ 与 p_{data} 相似？当模型密度 $p_\phi(x)$ 可计算时，一个自然想法是让观测数据在模型下获得较高密度。这导向最大似然估计（MLE）：选择 ϕ，使训练样本整体获得较高模型密度。[2]

一个标准的形式化方法是使用（正向）Kullback–Leibler 散度：[3]

$$\begin{aligned} D_{\text{KL}}(p_{\text{data}}\|p_\phi) &:= \int p_{\text{data}}(x)\log\frac{p_{\text{data}}(x)}{p_\phi(x)}\,dx \\ &= \mathbb{E}_{x\sim p_{\text{data}}}[\log p_{\text{data}}(x) - \log p_\phi(x)]. \end{aligned}$$

KL 散度不是对称的，即 $D_{\text{KL}}(p_{\text{data}}\|p_\phi) \neq D_{\text{KL}}(p_\phi\|p_{\text{data}})$。

乍看之下，由于数据密度 $p_{\text{data}}(x)$ 未知，正向 KL 似乎无法使用。然而，它可以分解为

$$\begin{aligned} D_{\text{KL}}(p_{\text{data}}\|p_\phi) &= \mathbb{E}_{x\sim p_{\text{data}}}\left[\log\frac{p_{\text{data}}(x)}{p_\phi(x)}\right] = -\mathbb{E}_{x\sim p_{\text{data}}}[\log p_\phi(x)] - H(p_{\text{data}}), \\ H(p_{\text{data}}) &:= -\mathbb{E}_{x\sim p_{\text{data}}}[\log p_{\text{data}}(x)], \end{aligned}$$

其中 $H(p_{\text{data}})$ 是数据分布的熵。关键在于这一项不依赖 ϕ。因此，即便我们无法计算 $p_{\text{data}}(x)$ 本身，也无需知道它便可优化模型参数。这给出以下等价关系：

引理 1.1.1 (最小化 KL 等价于 MLE)**.**

$$\min_\phi D_{\text{KL}}(p_{\text{data}}\|p_\phi) \quad\Longleftrightarrow\quad \max_\phi \mathbb{E}_{x\sim p_{\text{data}}}[\log p_\phi(x)]. \tag{1.1.2}$$

换言之，最小化正向 KL 散度等价于使真实数据样本在模型下获得较高的对数似然；这正是最大似然估计。

实践中，用假定独立同分布地抽自 p_{data} 的可用训练样本 $\{x^{(i)}\}_{i=1}^N$ 替换期望，得到经验负对数似然目标

$$\widehat{L}_{\text{MLE}}(\phi) := -\frac{1}{N}\sum_{i=1}^N \log p_\phi(x^{(i)}),$$

它可以通过小批量随机梯度优化。因此 MLE 只需要来自 p_{data} 的样本，不需要计算未知数据密度本身。

KL 散度的方向很重要，因为它决定在哪个分布上对差异取平均。对于正向 KL，

$$D_{\text{KL}}(p_{\text{data}}\|p_\phi) = \mathbb{E}_{x\sim p_{\text{data}}}\left[\log\frac{p_{\text{data}}(x)}{p_\phi(x)}\right],$$

期望对数据分布取值，所以模型必须考虑 p_{data} 中出现的区域。反向 KL $D_{\text{KL}}(p_\phi\|p_{\text{data}})$ 则对模型样本取平均。

这个区别有重要后果。假设存在区域 A，其数据概率为正 $p_{\text{data}}(A) > 0$，但模型在该处赋予零密度，即对 $x \in A$ 有 $p_\phi(x) = 0$。那么该区域上的 $\log[p_{\text{data}}(x)/p_\phi(x)] = +\infty$，正向 KL 因此为无穷大。所以，最小化正向 KL 会强烈惩罚完全遗漏数据分布中有概率质量区域的模型。这种行为通常称为*模式覆盖*。

[2]对固定观测样本 x，将 $p_\phi(x)$ 看作模型参数 ϕ 的函数时，称其为似然。对连续数据，$p_\phi(x)$ 是概率密度，而不是恰好观测到 x 的概率。

[3]所有积分均按 Lebesgue 意义理解，在计数测度下化为求和。

Fisher 散度。 Fisher 散度是（基于得分的）扩散建模的另一个重要概念（见第 3 章）。对两个分布 p, q，它定义为

$$D_{\mathrm{F}}(p\|q) := \mathbb{E}_{x\sim p}\left[\|\nabla_x \log p(x) - \nabla_x \log q(x)\|_2^2\right]. \tag{1.1.3}$$

它衡量得分函数 $\nabla_x \log p(x)$ 与 $\nabla_x \log q(x)$ 之间的差异；二者都是指向概率更高区域的向量场。简而言之，$D_{\mathrm{F}}(p\|q) \geq 0$，且等号当且仅当 $p = q$ 几乎处处成立。它对归一化常数不变，因为得分仅依赖对数密度的梯度；它构成得分匹配（式 (3.1.3) 与 (3.2.1)）的基础：该方法学习对数密度梯度以进行生成（基于得分的模型）。在这一设定下，数据分布 $p = p_{\mathrm{data}}$ 为目标，而训练模型 $q = p_\phi$ 以对齐其得分场。[4]

超越 KL。 尽管 KL 散度是衡量概率分布差异使用最广的指标，它并不是唯一选择。不同散度捕捉不同的几何或统计差异概念，从而影响学习算法的优化动力学。一个广泛的族是 f-散度（Csiszár，1963）：

$$D_f(p\|q) := \int q(x) f\left(\frac{p(x)}{q(x)}\right) dx, \qquad f(1) = 0, \tag{1.1.4}$$

其中 $f : \mathbb{R}_+ \to \mathbb{R}$ 是凸函数。改变 f 可得到许多著名散度：

$$\begin{aligned}
&f(u) = u\log u && \Longrightarrow D_f = D_{\mathrm{KL}}(p\|q) && \text{（正向 KL）},\\
&f(u) = \tfrac{1}{2}\left[u\log u - (u+1)\log\frac{1+u}{2}\right] && \Longrightarrow D_f = D_{\mathrm{JS}}(p\|q) && \text{（Jensen–Shannon）},\\
&f(u) = \tfrac{1}{2}|u-1| && \Longrightarrow D_f = D_{\mathrm{TV}}(p,q) && \text{（全变差）}.
\end{aligned}$$

为了清楚起见，其显式形式为

$$\begin{aligned}
D_{\mathrm{JS}}(p\|q) &= \tfrac{1}{2}D_{\mathrm{KL}}\big(p\big\|\tfrac{1}{2}(p+q)\big) + \tfrac{1}{2}D_{\mathrm{KL}}\big(q\big\|\tfrac{1}{2}(p+q)\big),\\
D_{\mathrm{TV}}(p,q) &= \tfrac{1}{2}\int_{\mathbb{R}^D} |p-q|\,dx = \sup_{A\subset\mathbb{R}^D} |p(A) - q(A)|.
\end{aligned}$$

直观地说，JS 散度提供一种平滑、对称的度量，平衡两个分布并避免 KL 的无界惩罚（我们以后会看到它有助于解释生成对抗网络 GAN 框架）；全变差距离则刻画两者之间可能出现的最大概率差。

另一种观点来自最优传输（见第 7 章），其代表是 Wasserstein 距离（见式 (7.2.2)）。它衡量把概率质量从一个分布移动到另一个分布的最小代价。与比较密度比的 f-散度不同，Wasserstein 距离依赖样本空间的几何结构，即使 p, q 的支集不相交也仍有意义。

每种散度体现了分布之间不同的接近性概念，因此诱导不同的学习行为。在本书后续生成建模的相关背景中，我们会在这些散度自然出现时再次讨论它们。

1.1.2 分布建模面临的挑战

为了对复杂的数据分布建模，我们可以用参数为 ϕ 的神经网络参数化概率密度函数 p_{data}，得到一个记为 p_ϕ 的模型。要使 p_ϕ 成为有效概率密度函数，必须满足两个基本性质：

[4]译注：等号当且仅当 $p = q$ 的结论通常需要对密度的正性、连通支集及正则性施加条件；若支集不连通，分量间的相对权重可能无法仅由支集内部的得分确定。

1. **非负性：**对于定义域内所有 x，都有 $p_\phi(x) \geq 0$。

2. **归一化：**整个定义域上的积分必须等于一，即 $\int p_\phi(x)\,dx = 1$。

网络可以自然地对输入 x 输出一个实标量 $E_\phi(x) \in \mathbb{R}$。为了把这个输出解释为有效密度，必须对其进行变换，以满足条件（1）和（2）。一种实用的替代办法是将 $E_\phi : \mathbb{R}^D \to \mathbb{R}$ 视为定义了一个未归一化密度，然后显式地强制满足这两个性质。

第 1 步：保证非负性。 对神经网络的原始输出 $E_\phi(x)$ 应用正值函数，例如 $|E_\phi(x)|$ 或 $E_\phi^2(x)$，即可保证模型输出始终非负。一个标准且方便的选择是指数函数，由此得到保证为正的未归一化密度 $\widetilde{p}_\phi(x)$：

$$\widetilde{p}_\phi(x) = \exp(E_\phi(x)).$$

第 2 步：强制归一化。 函数 $\widetilde{p}_\phi(x)$ 为正，但其积分不等于一。为了构造有效概率密度，必须除以它在整个空间上的积分。这得到模型的最终形式：

$$p_\phi(x) = \frac{\widetilde{p}_\phi(x)}{\int \widetilde{p}_\phi(x')\,dx'} = \frac{\exp(E_\phi(x))}{\int \exp(E_\phi(x'))\,dx'}.$$

该表达式的分母称为归一化常数或配分函数，记为 $Z(\phi)$：

$$Z(\phi) := \int \exp(E_\phi(x'))\,dx'.$$

尽管这一过程为 $p_\phi(x)$ 提供了一个有效的构造，它也带来重大计算挑战。对于大多数高维问题，计算归一化常数 $Z(\phi)$ 所需的积分难以处理。这种不可解性是推动许多不同深度生成模型家族发展的核心问题。

接下来的章节将介绍若干著名的深度生成建模方法。它们各自旨在绕过或降低计算这个归一化常数的代价。[5]

1.2 主要的深度生成模型

生成建模的核心挑战是学习具有表达能力的概率模型，使其能够捕捉高维数据丰富而复杂的结构。多年来，人们发展了各种建模策略，在可处理性、表达能力和训练效率之间作出不同权衡。本节探讨塑造这一领域、影响最深远的若干策略，并在图 1.2 中比较它们的计算图。

基于能量的模型（EBM）。 EBM（Ackley 等，1985；LeCun 等，2006）通过能量函数 $E_\phi(x)$ 定义概率分布：它对概率较高的数据点赋予较低能量。数据点的概率定义为

$$p_\phi(x) := \frac{1}{Z(\phi)} \exp(-E_\phi(x)), \qquad Z(\phi) = \int \exp(-E_\phi(x))\,dx,$$

其中 $Z(\phi)$ 是配分函数。训练 EBM 通常涉及最大化数据的对数似然，但这需要解决配分函数难以计算所带来的挑战。下一章我们会探索扩散模型如何提供另一种方法：利用对数密度梯度生成数据，该梯度不依赖归一化常数，从而绕过配分函数的计算。

[5]译注：归一化构造还要求 $Z(\phi)$ 有限且非零；指数函数输出为正本身并不保证在无界定义域上的可积性。原文此处未列明该条件。

自回归模型。 深度自回归（AR）模型（Frey 等，1995；Larochelle 和 Murray，2011；Uria 等，2016）基于一个简单而有力的观察：利用概率链式法则，任何联合分布都可以分解为一系列条件分布。给定变量 $x = (x_1, \ldots, x_D)$ 的一种顺序，数据分布满足

$$p_{\text{data}}(x) = \prod_{i=1}^{D} p_{\text{data}}(x_i \mid x_{<i}), \qquad x_{<i} = (x_1, \ldots, x_{i-1}).$$

重要的是，这种分解是精确恒等式，而非建模假设：对变量的任意选定顺序，任何联合分布都允许这样的分解。

挑战在于真实条件分布 $p_{\text{data}}(x_i \mid x_{<i})$ 未知。因此 AR 模型以相同的分解形式参数化模型：

$$p_\phi(x) = \prod_{i=1}^{D} p_\phi(x_i \mid x_{<i}),$$

并使用神经网络（例如 Transformer）从数据中逼近这些条件分布。例如，对离散数据，网络可以通过 softmax 输出类别分布；对连续数据，则可以输出易于处理的条件密度的参数。由于每个条件分布都已归一化，其乘积自动定义了归一化的联合分布。

这种构造也使基于似然的训练尤其简单。对于数据样本 x，对数似然分解为

$$\log p_\phi(x) = \sum_{i=1}^{D} \log p_\phi(x_i \mid x_{<i}),$$

所以可以直接通过最大似然训练模型，等价地也可以最小化负对数似然。训练时，观测到的前序变量 $x_{<i}$ 可用，因此通常可以并行计算许多这样的条件预测。

然而生成过程本质上仍是顺序的：

$$x_1 \sim p_\phi(x_1), \qquad x_2 \sim p_\phi(x_2 \mid x_1), \qquad \ldots \qquad x_D \sim p_\phi(x_D \mid x_{<D}).$$

因此，AR 模型提供可处理的精确似然和灵活的密度建模，但采样需要逐个生成变量，对长序列可能计算代价高昂。AR 模型仍是基于似然的生成模型的基础类别，也是许多现代序列模型和语言模型的基础。

变分自编码器（VAE）。 VAE（Kingma 和 Welling，2013）通过引入捕捉数据 x 中隐藏结构的潜变量 z，扩展经典自编码器。VAE 不直接学习 x 与 z 之间的映射，而采用概率观点：它同时学习一个编码器 $q_\theta(z \mid x)$，用于逼近给定数据时未知的潜变量分布；以及一个解码器 $p_\phi(x \mid z)$，用于从潜变量重构数据。为使训练可行，VAE 最大化真实对数似然的可处理替代目标，称为证据下界（ELBO）：

$$\mathcal{L}_{\text{ELBO}}(\theta, \phi; x) = \mathbb{E}_{q_\theta(z|x)}[\log p_\phi(x \mid z)] - D_{\text{KL}}(q_\theta(z \mid x) \| p_{\text{prior}}(z)).$$

其中第一项鼓励准确重构数据，第二项通过使潜变量接近简单先验分布 $p_{\text{prior}}(z)$（常为高斯分布）进行正则化。

VAE 为组合神经网络与潜变量模型提供了有原理依据的方法，仍是使用最广的基于似然的方法之一。但它也面临实际挑战，例如样本清晰度有限和训练病态（如解码器倾向于忽略潜变量）。尽管存在这些局限，VAE 仍为后续进展——包括扩散模型——奠定了重要基础。

归一化流。 经典的基于流的生成模型包括归一化流（NF）（Rezende 和 Mohamed，2015）及其基于神经常微分方程（NODE）的连续时间对应物（Chen 等，2018）。它们旨在通过可逆算子学习简单潜变量分布 z 与复杂数据分布 x 之间的双射 f_ϕ。实现方式可以是一系列双射变换（NF），也可以是将变换建模为常微分方程（NODE）。这些模型利用“密度变量替换公式”实现 MLE 训练：

$$\log p_\phi(x) = \log p(z) + \log\det \frac{\partial f_\phi^{-1}(x)}{\partial x},$$

其中 f_ϕ 是把 z 映射到 x 的可逆变换。NF 使用 Jacobian 行列式可处理的可逆变换，显式建模归一化密度。通过变量替换公式，归一化常数被解析地吸收，因此似然计算精确且可处理。[6]

尽管概念上优雅，经典流模型通常面临实际限制。例如，NF 通常对架构施加严格约束以保证双射，而 NODE 可能由于求解 ODE 的计算开销造成训练效率低下。两种方法在扩展到高维数据时都面临挑战。后续章节会探讨扩散模型如何与这些经典流方法相联系并以它们为基础。

生成对抗网络（GAN）。 GAN（Goodfellow 等，2014）由相互竞争的两个神经网络构成：生成器 G_ϕ 和判别器 D_ζ。生成器旨在从随机噪声 $z \sim p_{\text{prior}}$ 创造逼真样本 $G_\phi(z)$，判别器则试图区分真实样本 x 与生成样本 $G_\phi(z)$。GAN 的目标函数可表述为

$$\min_{G_\phi}\max_{D_\zeta} \quad \underbrace{\mathbb{E}_{x\sim p_{\text{data}}(x)}[\log D_\zeta(x)]}_{\text{真实}} + \underbrace{\mathbb{E}_{z\sim p_{\text{prior}}(z)}[\log(1 - D_\zeta(G_\phi(z)))]}_{\text{生成}}.$$

GAN 不定义显式密度函数，因而完全绕过似然估计。它们不计算归一化常数，而是着重生成与数据分布十分相似的样本。

从散度观点看，判别器隐式衡量真实数据分布 p_{data} 与生成器分布 p_{G_ϕ} 的差异；p_{G_ϕ} 表示将 $z \sim p_{\text{prior}}$ 输入 G_ϕ 所得到样本的分布。对固定生成器 G_ϕ，最优判别器为

$$D_\zeta^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_{G_\phi}(x)},$$

生成器的最小化归结为

$$\min_{G_\phi} \left(2D_{\text{JS}}(p_{\text{data}} \| p_{G_\phi}) - \log 4\right).$$

其中 Jensen–Shannon 散度定义为

$$D_{\text{JS}}(p\|q) := \tfrac{1}{2}D_{\text{KL}}\left(p \middle\| \tfrac{p+q}{2}\right) + \tfrac{1}{2}D_{\text{KL}}\left(q \middle\| \tfrac{p+q}{2}\right).$$

这表明 GAN 隐式最小化 $D_{\text{JS}}(p_{\text{data}}\|p_{G_\phi})$。更广泛地，诸如 f-GAN（Nowozin 等，2016）的扩展表明，对抗训练可以最小化一族 f-散度，从而将 GAN 与其他生成模型置于同一个散度最小化框架下。

虽然 GAN 能生成高质量数据，但其极小极大训练过程以不稳定著称，通常需要精心设计架构和工程技术才能取得令人满意的表现。不过，GAN 后来作为辅助组件重新得到应用，以增强其他生成模型，特别是扩散模型。

[6]译注：一般变量替换公式使用 Jacobian 行列式的绝对值；原式按源文保留，其写法需具备相应的行列式符号条件。另外图 1.2 的 NF 箭头把 f_ϕ 标作 $x \mapsto z$，与此处文字所说 $f_\phi : z \mapsto x$ 的约定相反。

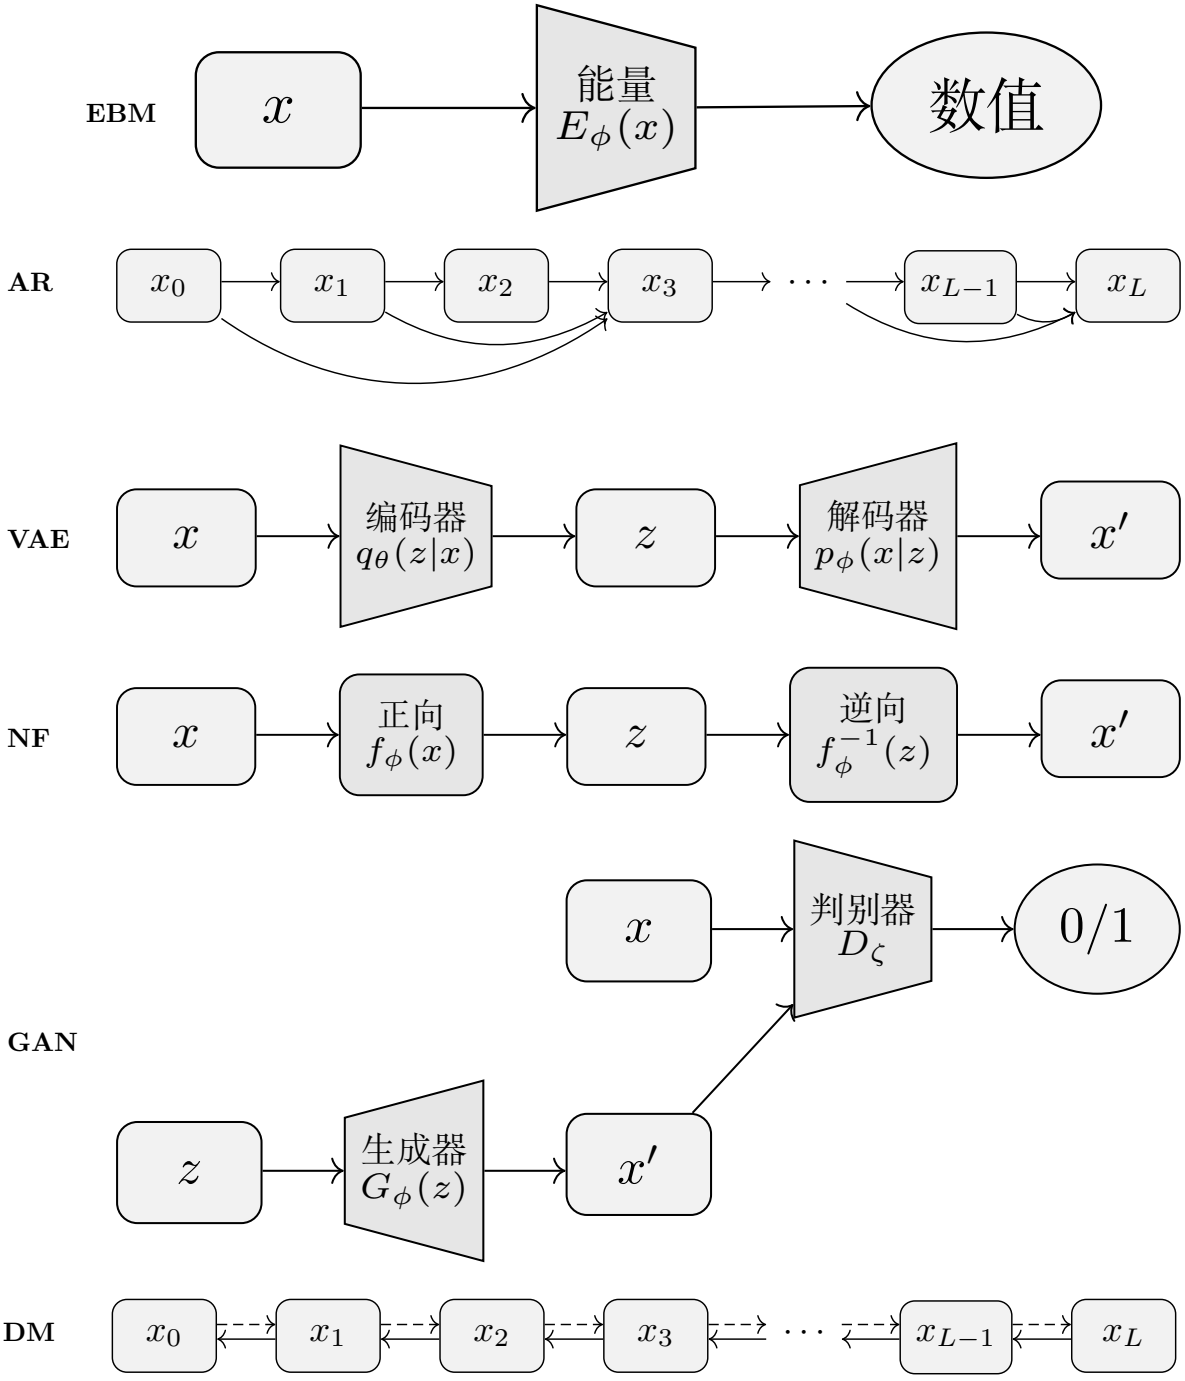


图 1.2: 主要深度生成模型的计算图。自上而下：EBM 将输入 x 映射为标量能量；AR 依因果依赖从左到右生成序列 $\{x_\ell\}_{\ell=0}^{L}$；VAE 将 x 编码为潜变量 z，再解码为重构 x'；NF 在 x, z 之间施加可逆映射 f_ϕ，并用 f_ϕ^{-1} 生成 x'；GAN 把噪声 z 转换为样本 x'，由判别器 D_ζ 与真实样本 x 比较；DM 通过多步去噪链 $\{x_\ell\}_{\ell=0}^{L}$ 迭代细化带噪样本。方框表示变量，梯形表示可学习网络，椭圆表示标量；箭头表示计算流。梯形原意用于表示改变维度的变换，而矩形表示变量或保持维度的映射。原图文字 Energy、Encoder、Decoder、Forward、Inverse、Generator、Discriminator 分别为能量、编码器、解码器、正向、逆向、生成器和判别器。来源：作者绘制。

1.3 建模的分类

如前所见，DGM 包含范围广泛的建模策略。一个根本区别在于这些模型如何参数化底层数据分布：也就是说，无论训练目标是什么，它们是显式还是仅隐式地指定 $p_\phi(x)$。

- **显式模型：**这些模型通过可处理或近似可处理的密度或质量函数，直接参数化概率分布 $p_\phi(x)$。例如 AR、NF、VAE 和扩散模型（DM）；它们均以精确方式或通过可处理的界定义 $p_\phi(x)$。

- **隐式模型：**这些模型只通过采样过程指定分布，典型形式为 $x = G_\phi(z)$，其中噪声变量 $z \sim p_{\text{prior}}$。此时 $p_\phi(x)$ 没有封闭形式，甚至可能根本没有定义。

表 1.1 简洁总结了这两类方法。

表 1.1: 显式与隐式生成模型的比较

	显式		隐式
	精确似然	近似似然	
似然	可处理	界 / 近似	不直接建模 / 难处理
目标	MLE	ELBO	对抗目标
例子	NF、AR	VAE、DM	GAN

与扩散模型的联系。 综合来看，这些经典 DGM 家族展示了对复杂分布建模的互补策略。它们除了本身的重要性，还为理解扩散模型提供了指导原则。扩散方法继承了其中多种观点的思想：通过变分训练目标与 VAE 联系，通过学习对数密度梯度（与能量函数密切相关）的得分匹配方法与 EBM 联系，通过连续时间变换与 NF 联系。

为给后面章节的扩散方法奠定基础，我们将重点讨论三个核心范式：VAE（第 2.1 节）、EBM（第 3.1 节）和 NF（第 5.1 节）。这些内容为理解现代扩散生成建模的核心原理提供基础；本书后文将继续展开这些原理。

1.4 结束语

本章建立了深度生成建模的基本概念。我们首先定义首要目标：学习一个以 ϕ 参数化、可处理的模型分布 p_{model}，用以逼近未知且复杂的数据分布 p_{data}。核心挑战是定义有效概率密度所需的归一化常数或配分函数 $Z(\phi)$ 在计算上难以处理。

为绕过这一问题，人们发展了多种深度生成模型家族，每种都采用不同策略。我们介绍了几种主要方法，包括基于能量的模型（EBM）、自回归模型（AR）、变分自编码器（VAE）、归一化流（NF）和生成对抗网络（GAN）。这些模型大体可分为定义可处理密度的显式模型，与只通过采样过程定义分布的隐式模型。

每个经典框架都有其重要性，但其中三个尤其是本书所关注扩散模型的概念起源：VAE、EBM 和 NF。接下来的章节将沿三个基础范式追溯扩散模型的演化：

1. B 部首先探讨变分观点（第 2 章），展示 VAE 的层级潜变量结构如何自然导出去噪扩散概率模型（DDPM）。

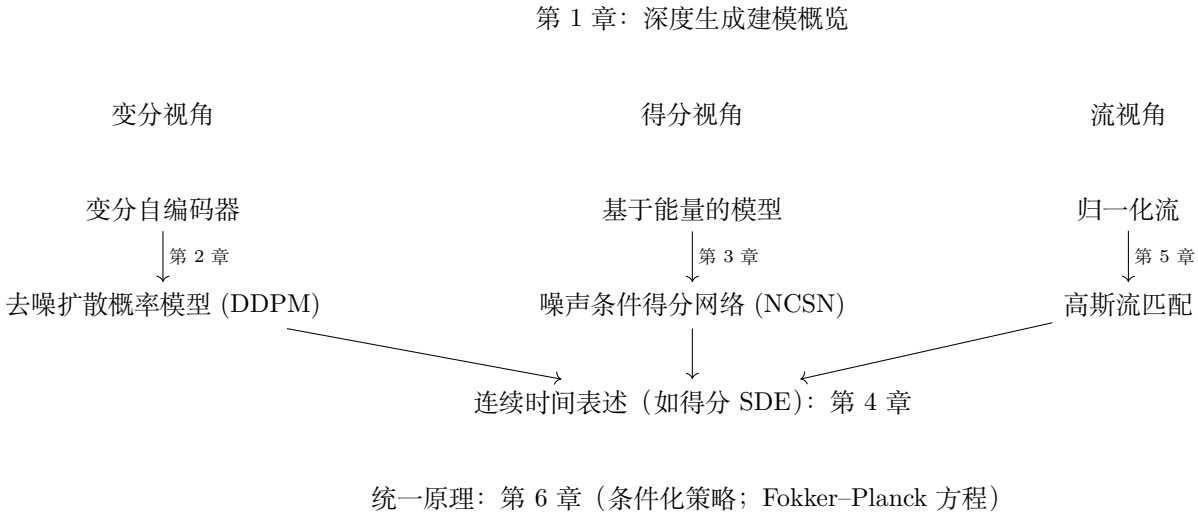
2. 随后考察基于得分的观点（第 3 章）：它起源于 EBM 和得分匹配，发展成噪声条件得分网络（NCSN）及更一般的 Score SDE 框架（第 4 章）。

3. 最后研究基于流的观点（第 5 章）：它以归一化流的原理为基础，将生成表述为连续变换，并由流匹配概念推广。

理解这些起源后，我们将建立一个连贯框架，用以解释扩散模型的多种表述，揭示将其统一起来的深层原理。

第二部分

扩散模型的基础与视角



B 部阅读路线图。原图左侧按行区分 “视角” “起源” 和 “扩散模型”：变分、得分和流三条路径汇入连续时间表述，再通向统一原理。依原 PDF 印页 31 重建，保留原节点与箭头方向。

扩散模型训练与采样的初步操作图景

在深入扩散模型的数学之前，我们先建立一个简单的操作图景，了解模型如何训练，又如何生成样本。

基本构造包含两部分。首先，定义一个已知的污染规则，使干净数据在任意选定的噪声水平变成含噪观测。其次，训练神经网络，根据这样的含噪观测推断干净信号。在许多噪声水平上学会这一预测规则后，也可以将其用于生成：从一个新的噪声样本出发，在从高到低移动噪声水平的同时反复应用网络，结果就是一个逐渐获得数据分布结构的新样本。

> **要点：**在许多噪声水平上制造含噪数据，学习预测干净信号，再从高噪声到低噪声反复应用这一预测来生成样本。

制造含噪数据。 先精确定义什么是数据的含噪版本。取一个干净数据样本，例如一幅图像或其他我们关心的数据：

$$x_0 \sim p_{\text{data}}.$$

在噪声水平 t，混入独立高斯噪声使其受到污染：[7]

$$x_t = \alpha_t x_0 + \sigma_t \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I).$$

可以把预先固定的 α_t 和 σ_t 想象为两个旋钮，设定噪声水平 t 时混入多少干净信号和噪声。最简单的选择是 $\alpha_t = 1$、$\sigma_t = t$，这给出

$$x_t = x_0 + t\epsilon.$$

此时 t 就是字面意义上的噪声旋钮：使其趋近零，x_t 就几乎是干净样本；增大它，噪声项 $t\epsilon$ 就越来越占主导。

更一般地，每个噪声水平 t 都在含噪样本上定义一个分布 p_t。可以把 p_t 看成一张快照：若用相同的 t 值生成许多含噪样本，其分布就是 p_t。调度 (α_t, σ_t) 的选择使这些快照从干净数据逐渐移向一个简单的噪声分布：

$$p_0 = p_{\text{data}} \quad \longrightarrow \quad p_t \quad \longrightarrow \quad p_T \approx p_{\text{prior}}.$$

其中 p_{prior} 通常是易于采样的高斯分布。因此，族 $\{p_t\}_{t\in[0,T]}$ 描述了分布随噪声水平增加而逐渐变化的过程。

训练：学习预测干净信号。 有了污染数据的方法，训练就几乎成为机械操作，其关键技巧在于：由于污染由我们施加，我们始终知道正确答案。构造单个训练实例时，先抽取干净数据 x_0，选择噪声水平 t，抽取噪声 ϵ，再构造

$$x_t = \alpha_t x_0 + \sigma_t \epsilon.$$

[7]公式 $x_t = \alpha_t x_0 + \sigma_t \epsilon$ 直接给出选定噪声水平 t 的累积污染。在 DDPM 和得分 SDE 中，也可以通过许多较小的顺序加噪步骤得到同一水平的边缘分布，参见第 2.2 节和第 4 章。后文离散 DDPM 记号将这一累积污染写成 $x_i = \bar{\alpha}_i x_0 + \sqrt{1-\bar{\alpha}_i^2}\epsilon$。

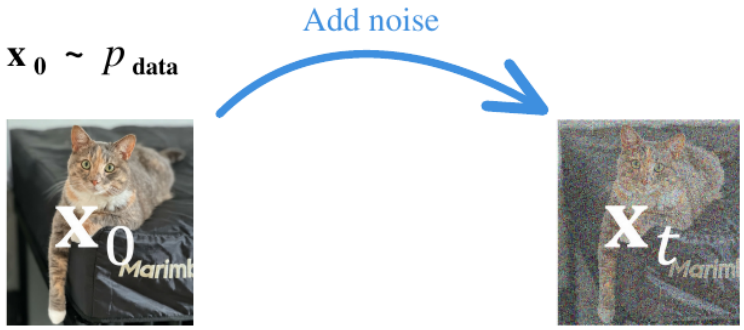


图 1.3: 正向扩散。干净样本 x_0 受到污染，在噪声水平 t 产生含噪观测 x_t；图内 Add noise 表示“加噪”。来源：作者绘制。

x_t 是我们亲手制造的，所以我们准确知道它由哪个干净 x_0 产生。然而网络从不直接看到 x_0 或 ϵ。它只看到 (x_t, t)，即受到污染的观测以及污染程度。它的任务是猜测背后的干净数据：

$$x_0^{\text{pred}} := x_\phi(x_t, t).$$

由于真实目标已知，可以用普通平方误差损失评价并改进这一猜测：

$$\|x_0^{\text{pred}} - x_0\|_2^2.$$

> **要点：**制造一个干净目标已知的含噪观测，将目标对网络隐藏，再训练网络预测这一目标。

对不同的数据样本、噪声抽样和噪声水平反复执行上述过程，一个网络就能在从几乎未受污染到几乎纯噪声的整个范围内预测干净数据。

值得停下来看看，这个损失究竟教网络预测什么。在平方误差下，最优预测为

$$x_0^*(x_t, t) = \mathbb{E}[x_0 \mid x_t, t].$$

含噪观测一般并不唯一对应某个干净样本。多个不同的干净样本都可能产生相似的 x_t。任何非零噪声水平都存在这种歧义，噪声较高时尤其严重。因此，网络学习的是对给定当前含噪观测后仍然合理的干净样本取平均。[8]

采样：从新的噪声出发。 训练得到一个善于从含噪数据猜测干净数据的网络。接下来要问，如何利用这项本领生成新东西。训练结束后，冻结网络参数，记作 $\phi^\times$。生成沿着与上述过程相反的方向运行：从纯噪声出发，

$$\widetilde{x}_T \sim p_{\text{prior}},$$

而不是从数据出发加噪。波浪号标记生成状态 $\widetilde{x}_t$，使其在视觉上区别于正向污染得到的训练变量 x_t。

这个区别比初看起来更重要。$\widetilde{x}_T$ 并不是某个真实、隐藏样本被暗中污染的结果，背后没有等待恢复的真实 x_0。因此，生成并不是将某次特定污染的录像倒放，因为这样的录像根本不存

[8]噪声水平由上下文明确时，通常简记为 $\mathbb{E}[x_0 \mid x_t]$。

在。我们只是在每个噪声水平询问训练后的网络：当前它认为干净信号是什么样子，再据此朝数据方向迈出一步。

具体地，设当前状态为 $\widetilde{x}_t$，送入网络后得到干净数据猜测：

$$x_0^{\text{pred}} := x_{\phi^\times}(\widetilde{x}_t, t).$$

当 $t > 0$ 时，还可计算隐含的噪声残差，即从当前状态移去预测信号后剩余的部分：

$$\epsilon_t^{\text{pred}} := \frac{\widetilde{x}_t - \alpha_t x_0^{\text{pred}}}{\sigma_t}.$$

这两个量并非独立猜测：按构造，它们恰好重新组成当前状态，

$$\widetilde{x}_t = \alpha_t x_0^{\text{pred}} + \sigma_t \epsilon_t^{\text{pred}}.$$

单次采样步骤的想法是：保持预测信号和预测噪声不变，却将系数改为略低噪声水平 $t - \Delta t$ 的值，再次混合：

$$\widetilde{x}_{t-\Delta t} = \alpha_{t-\Delta t} x_0^{\text{pred}} + \sigma_{t-\Delta t} \epsilon_t^{\text{pred}}.$$

等价地，这是在当前状态之上的一个小更新：

$$\widetilde{x}_{t-\Delta t} = \widetilde{x}_t + (\alpha_{t-\Delta t} - \alpha_t) x_0^{\text{pred}} + (\sigma_{t-\Delta t} - \sigma_t) \epsilon_t^{\text{pred}}. \tag{1.4.1}$$

这就完成了一步。把新状态 $\widetilde{x}_{t-\Delta t}$ 再送回网络，得到通常有所不同的干净数据预测，再向下一个较低噪声水平迈进。从 $t = T$ 到 $t = 0$ 反复执行这一循环，就是采样。

要点：从新噪声出发，预测干净信号，走到较低噪声水平，再次预测。

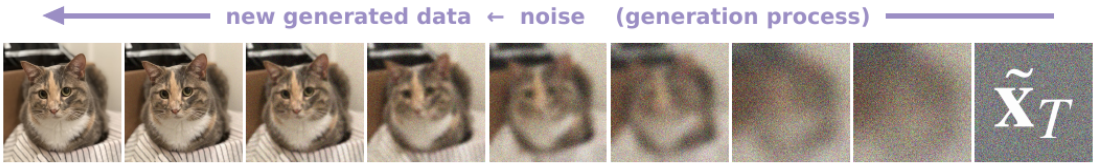


图 1.4: 扩散生成。从新的噪声 $\widetilde{x}_T \sim p_{\text{prior}}$ 出发，随噪声水平降低反复使用模型预测，构建新样本。图中文字表示“新生成的数据 ← 噪声（生成过程）”。来源：作者绘制。

一个自然的问题是：为何不直接输出第一次预测 x_0^{pred} 然后停止？因为高噪声水平的当前状态几乎不含干净结构的信息，预测不过是对许多合理样本作粗略平均。移到略低噪声水平，网络就能处理歧义略少的状态，使下一次预测更清晰。反复这样做，才使细节丰富的样本逐渐出现。[9]

[9]第 9.2 节将这一确定性更新与 DDIM 采样及其 Euler 型解释联系起来（Song et al., 2020a）；随机 DDPM 采样器将在第 2.2 节介绍。

一个简单例子。　沿用前面的 $\alpha_t = 1$、$\sigma_t = t$，代入上述更新可得

$$\begin{aligned}\widetilde{x}_{t-\Delta t} &= x_0^{\text{pred}} + (t - \Delta t)\frac{\widetilde{x}_t - x_0^{\text{pred}}}{t} \\ &= \frac{t - \Delta t}{t}\widetilde{x}_t + \frac{\Delta t}{t}x_0^{\text{pred}}.\end{aligned}$$

换言之，Δt 较小时，下一状态只是当前位置和网络认为应到达位置的混合。每一步都把样本推向网络当前预测为干净的信号。“当前”二字很关键：移动后，网络看到新的、噪声更少的状态，通常会改变预测。因此最终样本并非单次干净数据猜测的输出，而是来自一系列猜测，每个猜测都根据上一步的结果修订。

与后续各章的联系。　这里建立的干净数据预测模板只是初步操作图景。全书的基本模式相同：训练时，从干净数据制造含噪观测，学习从中预测有用信息；生成时，从新噪声出发，在递减的噪声水平上利用学得的预测构造新样本。

后续各章从不同数学视角解释同一过程。第 二章把 DDPM 与潜变量模型联系起来，固定加噪过程扮演编码器，学得的反向转移扮演解码器。第 3 章用得分描述去噪，为更新含噪样本提供方向。第 4 章从离散噪声水平进入连续时间，用逆时间随机动力学描述生成。第 5 章将生成看成沿连续路径把简单先验的样本输运到数据分布。最后，第 6 章解释这些视角之间的联系。

主要结论很简单：扩散模型从许多噪声水平的数据含噪版本中学习，生成则反复使用学得的预测，把新噪声变成新样本。

第二章　变分视角：从 VAE 到 DDPM

本章从变分视角考察扩散模型。我们从变分自编码器（VAE）开始：它用潜变量表示数据，通过最大化对数似然的一个可计算下界进行训练。学得的编码器将观测映射到潜变量，学得的解码器再将潜变量映射回观测，闭合建模循环。

在此基础上，层次变分自编码器（HVAE）堆叠多个潜变量层，捕捉多个尺度的结构。在这一设定下，去噪扩散概率模型（DDPM）在概念上遵循相似模板：它不联合训练编码器和解码器，而将编码器固定为逐渐把数据变成噪声的正向加噪过程，训练则学习一个通过连续去噪步骤逆转这一路径的解码器。因此，VAE、HVAE 和扩散模型都优化由变分界定义的似然替代目标，这为本章的方法提供共同基础。

学完本章后，你将能够：

- 理解为什么精确最大似然训练困难时，VAE 转而优化证据下界 ELBO；
- 理解 DDPM 如何以固定加噪过程和学得的反向过程，将 VAE 的潜变量视角扩展到许多含噪层；
- 理解如何用条件化技巧，把困难的反向去噪问题化为可计算的训练目标；
- 比较均值预测、干净数据预测和噪声预测，理解它们如何表示相同的底层去噪信息；
- 通过 ELBO，将实用 DDPM 去噪损失与其变分基础联系起来。

阅读路线。　已经熟悉 VAE 和 ELBO 训练的读者可以略读第 2.1 节，直接从第 2.2 节开始。

2.1　变分自编码器

神经网络如何学习生成逼真的数据？自然的起点是自编码器：它包含两个网络，一个确定性编码器将输入压缩成低维潜在编码，另一个确定性解码器从编码重建输入。训练最小化原输入与重建结果之间的重建误差。虽然这样可以准确重建，但潜在空间没有结构，随机抽取潜在编码通常得到无意义的输出，限制了其生成用途。

变分自编码器（VAE）（Kingma and Welling, 2013）通过给潜在空间施加概率结构解决这一问题，将模型从简单的重建工具变成能够产生新颖、逼真数据的生成模型。

$$x \longrightarrow \underset{q_\theta(z|x)}{\text{编码器}} \longrightarrow z \longrightarrow \underset{p_\phi(x|z)}{\text{解码器}} \longrightarrow x'$$

图 2.1: VAE 示意图。随机编码器 $q_\theta(z \mid x)$ 将数据 x 映射到潜变量 z，解码器 $p_\phi(x \mid z)$ 从潜变量重建数据。来源：作者绘制；依原图重建。

2.1.1 概率编码器与解码器

解码器（生成器）的构造。 VAE 区分两类变量：观测变量 x 对应可见数据（如图像），潜变量 z 则捕捉隐藏的变化因素（如物体形状、颜色或风格）。模型假设，每个观测 x 都由一个从简单先验分布抽取的潜变量产生；先验通常取标准高斯分布 $z \sim p_{\text{prior}} := \mathcal{N}(0, I)$。

为将 z 映射回数据空间，定义解码器（生成器）分布 $p_\phi(x \mid z)$。实践中令解码器保持简单，常取因子化高斯分布（见第 2.1.3 节）或类似分布，让学习集中于提取有用潜在特征，而不是记忆数据。直观地说，直接逐像素生成极为困难；潜变量提供了紧凑表示，从中解码出精确像素排列则容易得多。生成新样本时，先抽取 $z \sim p_{\text{prior}}$，再按 $x \sim p_\phi(x \mid z)$ 解码。

VAE 因此通过边缘似然定义潜变量生成模型：

$$p_\phi(x) = \int p_\phi(x \mid z) p(z)\, dz.$$

理想情况下，与最大似然估计一样，最大化这一边缘似然来学习解码器参数 ϕ（见式 (1.1.2)）。然而，对表达能力强的非线性解码器，关于 z 的积分难以计算，直接 MLE 在计算上不可行，因此需要 VAE 的变分方法。

编码器（推断网络）的构造。 要把难以计算的生成器与真实数据联系起来，考虑逆问题：给定观测 x，哪些潜在编码 z 可能产生它？由 Bayes 规则，后验分布为

$$p_\phi(z \mid x) = \frac{p_\phi(x \mid z) p(z)}{p_\phi(x)}.$$

困难在于分母包含边缘似然 $p_\phi(x)$，需要对所有潜变量积分，对非线性解码器难以计算。因此，从 x 对 z 作精确推断在计算上代价过高。

VAE 的“变分”步骤用可计算近似代替难以计算的后验。引入由神经网络参数化的编码器（或推断网络）$q_\theta(z \mid x)$，作为可学习的替代：

$$q_\theta(z \mid x) \approx p_\phi(z \mid x).$$

实践中，编码器将每个观测数据点 x 映射为潜在编码上的一个分布，提供从 x 返回 z 的可行、可训练路径，使学习成为可能。

2.1.2 通过证据下界（ELBO）训练

现在定义一个可计算的训练目标。虽然不能直接优化 $\log p_\phi(x)$，但可以最大化它的一个下界，即证据下界（ELBO）。

定理 2.1.1 (证据下界（ELBO）)**.** *对于任意数据点 x，对数似然满足*

$$\log p_\phi(x) \geq \mathcal{L}_{\text{ELBO}}(\theta, \phi; x),$$

其中

$$\mathcal{L}_{\mathrm{ELBO}} = \underbrace{\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x \mid z)]}_{\text{重建项}} - \underbrace{D_{\mathrm{KL}}(q_\theta(z \mid x)\|p(z))}_{\text{潜变量正则化}}. \tag{2.1.1}$$

证明. ELBO 来自 Jensen 不等式：

$$\begin{aligned}\log p_\phi(x) &= \log \int p_\phi(x,z)\,dz = \log \int q_\theta(z \mid x)\frac{p_\phi(x,z)}{q_\theta(z \mid x)}\,dz \\ &= \log \mathbb{E}_{z\sim q_\theta(z|x)}\left[\frac{p_\phi(x,z)}{q_\theta(z \mid x)}\right] \geq \mathbb{E}_{z\sim q_\theta(z|x)}\left[\log \frac{p_\phi(x,z)}{q_\theta(z \mid x)}\right].\end{aligned}$$

□

ELBO 自然分解成两部分：

- **重建项：**鼓励从潜在编码 z 准确恢复 x。在高斯编码器和解码器假设下，它恰好化为熟悉的自编码器重建损失（参见第 2.1.3 节）。但与自编码器相同，只优化这一项有记忆训练数据的风险，因此需要额外正则化。
- **潜变量 KL 项：**鼓励编码器分布 $q_\theta(z \mid x)$ 接近简单高斯先验 $p_{\mathrm{prior}}(z)$。这一正则化将潜在空间塑造成平滑、连续的结构，使从先验抽取的样本能够可靠解码，从而支持有意义的生成。

这一权衡兼顾忠实重建和协调一致的采样。

信息论视角：ELBO 作为散度界。 ELBO 有自然的信息论解释。回忆最大似然训练等价于最小化

$$D_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x)),$$

衡量模型分布对数据分布的近似程度。它一般难以计算，因此变分框架引入联合分布之间的比较。具体考虑

- 生成联合分布 $p_\phi(x,z) = p(z)p_\phi(x \mid z)$，描述模型如何生成数据；
- 推断联合分布 $q_\theta(x,z) = p_{\mathrm{data}}(x)q_\theta(z \mid x)$，将真实数据与推断出的潜变量耦合。

比较二者得到

$$D_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x)) \leq D_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z)). \tag{2.1.2}$$

这有时称为 KL 散度的链式法则。直观地，只比较边缘变量 x 可能掩盖某些不匹配，而比较完整的潜变量—数据联合分布会揭示它们。形式上，将联合 KL 展开为

$$\begin{aligned}\underbrace{D_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))}_{\text{总误差界}} &= \mathbb{E}_{q_\theta(x,z)}\left[\log \frac{p_{\mathrm{data}}(x)q_\theta(z \mid x)}{p_\phi(x)p_\phi(z \mid x)}\right] \\ &= \mathbb{E}_{p_{\mathrm{data}}(x)}\left[\log \frac{p_{\mathrm{data}}(x)}{p_\phi(x)} + D_{\mathrm{KL}}(q_\theta(z \mid x)\|p_\phi(z \mid x))\right] \\ &= \underbrace{D_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi)}_{\text{真实建模误差}} + \underbrace{\mathbb{E}_{p_{\mathrm{data}}(x)}[D_{\mathrm{KL}}(q_\theta(z \mid x)\|p_\phi(z \mid x))]}_{\text{推断误差}}.\end{aligned}$$

第一项是真实建模误差，第二项是推断误差，即近似后验与真实后验之间的差距。后者始终非负，由此得到式 (2.1.2)。最后，注意

$$\log p_\phi(x) - \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; x) = D_{\mathrm{KL}}(q_\theta(z \mid x) \| p_\phi(z \mid x)).$$

因此推断误差恰好是对数似然与 ELBO 的间隙。最大化 ELBO 因而对应于直接减小推断误差，保证训练最小化总界中有意义的一部分。[1]

2.1.3 高斯 VAE

VAE 的一种标准表述将编码器和解码器都设为高斯分布。

编码器部分。 通常建模为

$$q_\theta(z \mid x) := \mathcal{N}\big(z; \mu_\theta(x), \mathrm{diag}(\sigma_\theta^2(x))\big),$$

其中 $\mu_\theta : \mathbb{R}^D \to \mathbb{R}^d$、$\sigma_\theta : \mathbb{R}^D \to \mathbb{R}^d_+$ 是编码网络的确定性输出。

解码器部分。 通常取具有固定方差的高斯分布：

$$p_\phi(x \mid z) := \mathcal{N}(x; \mu_\phi(z), \sigma^2 I),$$

其中 $\mu_\phi : \mathbb{R}^d \to \mathbb{R}^D$ 为神经网络，$\sigma > 0$ 是控制方差的小常数。此时 ELBO 的重建项简化为

$$\mathbb{E}_{q_\theta(z|x)}[\log p_\phi(x \mid z)] = -\frac{1}{2\sigma^2}\mathbb{E}_{q_\theta(z|x)}[\|x - \mu_\phi(z)\|^2] + C,$$

C 与 θ, ϕ 无关。因此目标化为

$$\min_{\theta,\phi} \quad \mathbb{E}_{q_\theta(z|x)}\left[\frac{1}{2\sigma^2}\|x - \mu_\phi(z)\|^2\right] + D_{\mathrm{KL}}(q_\theta(z \mid x) \| p_{\mathrm{prior}}(z)).$$

由于高斯假设，KL 项存在闭式解。因此，训练 VAE 化为最小化一个正则化重建损失。

2.1.4 标准 VAE 的缺点

尽管 VAE 框架在理论上很有吸引力，它有一个关键缺点：输出经常模糊。[2]

VAE 生成中的模糊。 考虑固定高斯编码器 $q_{\mathrm{enc}}(z \mid x)$，以及如下解码器：

$$p_{\mathrm{dec}}(x \mid z) = \mathcal{N}(x; \mu(z), \sigma^2 I),$$

[1]译注：固定生成参数 ϕ 时，关于 θ 最大化 ELBO 等价于减小此间隙。若联合改变 ϕ，$\log p_\phi(x)$ 也变化，不能据此断言推断误差在每个优化步骤都下降。此处保留原文解释。

[2]这里研究的局限专属于上述常见 VAE 设定：简单高斯解码器通过平方重建误差训练。总体最优解码器返回条件均值。若多个视觉上不同的输入对应重叠的潜在区域，平均就可能表现为模糊。这并不是关于每种 VAE 架构或观测模型的普遍断言。

其中 $\mu(z)$ 表示解码器网络。对任意给定编码器，优化 ELBO 等价于最小化期望重建误差（相差加法常数）：

$$\arg\min_{\mu} \quad \mathbb{E}_{p_{\text{data}}(x)q_{\text{enc}}(z|x)}[\|x-\mu(z)\|^2].$$

这是关于 $\mu(z)$ 的标准最小二乘问题，闭式解为条件均值：

$$\mu^*(z)=\mathbb{E}_{q_{\text{enc}}(x|z)}[x],$$

其中给定潜变量时输入的编码器诱导后验由 Bayes 规则定义：

$$q_{\text{enc}}(x\mid z)=\frac{q_{\text{enc}}(z\mid x)p_{\text{data}}(x)}{q_{\text{enc}}(z)}, \qquad q_{\text{enc}}(z):=\int q_{\text{enc}}(z\mid x)p_{\text{data}}(x)\,dx.$$

再次使用 Bayes 规则，最优生成器等价地写成

$$\mu^*(z)=\frac{\mathbb{E}_{p_{\text{data}}(x)}[q_{\text{enc}}(z\mid x)\,x]}{q_{\text{enc}}(z)}=\frac{\mathbb{E}_{p_{\text{data}}(x)}[q_{\text{enc}}(z\mid x)\,x]}{\mathbb{E}_{p_{\text{data}}(x)}[q_{\text{enc}}(z\mid x)]}.$$

若两个不同输入 $x\neq x'$ 映射到重叠潜在区域，即 $q_{\text{enc}}(\cdot\mid x)$ 与 $q_{\text{enc}}(\cdot\mid x')$ 的支集相交，则 $\mu^*(z)$ 会对多个可能互不相关的输入取平均，导致模糊、不鲜明的输出。对相互冲突模式的平均，是 VAE 生成样本具有典型模糊性的一个根本原因。

2.1.5 （可选）从标准 VAE 到层次 VAE

为了建模复杂数据，层次变分自编码器（HVAE）（Vahdat and Kautz, 2020）引入潜变量层次，增强 VAE。深的分层结构使模型能够捕捉多个抽象层次的数据特征，大幅增强表达能力，并对应真实数据的组合性质。

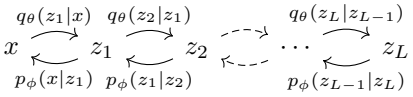


图 2.2: HVAE 的计算图。它具有层次结构，在多个潜变量层之间堆叠可训练编码器和解码器。来源：作者绘制；依原图重建。

HVAE 的建模。 标准 VAE 使用单个潜在编码 z，HVAE 则引入按自顶向下层次排列的多层潜变量。每层潜变量作为其下方一层的条件，形成条件先验链，捕捉逐渐细化抽象层次的结构。联合分布具有自顶向下分解：

$$p_\phi(x,z_{1:L})=p_\phi(x\mid z_1)\prod_{i=2}^{L}p_\phi(z_{i-1}\mid z_i)p(z_L).$$

它定义边缘数据分布

$$p_{\text{HVAE}}(x):=\int p_\phi(x,z_{1:L})\,dz_{1:L}.$$

生成逐层进行：从顶层潜变量 z_L 出发，逐个向下解码到 z_1，最后生成观测 x。编码部分使用结构化、可学习的变分编码器 $q_\theta(z_{1:L}\mid x)$，对应生成层次。常见选择是自底向上的 Markov 分解：

$$q_\theta(z_{1:L}\mid x)=q_\theta(z_1\mid x)\prod_{i=2}^{L}q_\theta(z_i\mid z_{i-1}).$$

HVAE 的 ELBO。 与式 (2.1.1) 相似，由 Jensen 不等式，

$$\begin{aligned}\log p_{\mathrm{HVAE}}(x) &= \log \int p_\phi(x, z_{1:L})\, dz_{1:L} \\ &= \log \int \frac{p_\phi(x, z_{1:L})}{q_\theta(z_{1:L} \mid x)} q_\theta(z_{1:L} \mid x)\, dz_{1:L} \\ &= \log \mathbb{E}_{q_\theta(z_{1:L}|x)} \left[\frac{p_\phi(x, z_{1:L})}{q_\theta(z_{1:L} \mid x)} \right] \\ &\geq \mathbb{E}_{q_\theta(z_{1:L}|x)} \left[\log \frac{p_\phi(x, z_{1:L})}{q_\theta(z_{1:L} \mid x)} \right] =: \mathcal{L}_{\mathrm{ELBO}}(\phi). \end{aligned} \tag{2.1.3}$$

代入分解形式，得到

$$\mathcal{L}_{\mathrm{ELBO}} = \mathbb{E}_{q_\theta(z_{1:L}|x)} \left[\log \frac{p(z_L) \prod_{i=2}^{L} p_\phi(z_{i-1} \mid z_i) p_\phi(x \mid z_1)}{q_\theta(z_1 \mid x) \prod_{i=2}^{L} q_\theta(z_i \mid z_{i-1})} \right].$$

这个层次 ELBO 分解为具有明确解释的项，包括重建项、相邻层匹配项，以及针对先验的顶层 KL 正则化项。

由浅层到深层网络的飞跃改变了机器学习，相似思想也改变了生成模型。HVAE 展示了用深的堆叠层构造数据的力量。分层思想是现代生成建模的基石，在得分方法（第 3.4 节）和归一化流（第 5.1 节）中也会出现。核心洞见简单而有力：

观察 2.1.1. 堆叠多层使模型能够逐步生成数据，从粗略细节开始，每一步再添加更精细的细节。这使捕捉高维数据的复杂结构容易得多。

为什么只加深扁平 VAE 的网络还不够？ 标准扁平 VAE 有两个根本局限，不能仅靠加深编码器和解码器解决。

第一个局限是变分族。标准 VAE 中，

$$q_\theta(z \mid x) = \mathcal{N}\big(z; \mu_\theta(x), \mathrm{diag}(\sigma_\theta^2(x))\big),$$

所以对每个固定 x，编码器后验始终是单个对角协方差高斯。更深网络提高 μ_θ 和 σ_θ 的精度，却不扩展分布族；即使使用完整协方差，仍只有一个单峰椭球。当 $p_\phi(z \mid x)$ 多峰时，这个族无法匹配它，使 ELBO 变松、推断变弱。解决这一问题需要更丰富的后验类别，而不只是更深的网络。

第二，如果解码器表达能力过强，可能出现后验坍缩。回忆 VAE 目标：

$$\begin{aligned}\mathbb{E}_{p_{\mathrm{data}}(x)}[\mathcal{L}_{\mathrm{ELBO}}(x)] &= \mathbb{E}_{p_{\mathrm{data}}(x) q_\theta(z|x)}[\log p_\phi(x \mid z)] \\ &\quad - \mathbb{E}_{p_{\mathrm{data}}(x)}[D_{\mathrm{KL}}(q_\theta(z \mid x) \| p(z))] \\ &= \mathbb{E}_{p_{\mathrm{data}}(x) q_\theta(z|x)}[\log p_\phi(x \mid z)] - I_q(x; z) - D_{\mathrm{KL}}(q_\theta(z) \| p(z)),\end{aligned}$$

其中互信息定义为

$$I_q(x; z) = \mathbb{E}_{q(x,z)} \left[\log \frac{q_\theta(z \mid x)}{q(z)} \right] = \mathbb{E}_{p_{\mathrm{data}}(x)}[D_{\mathrm{KL}}(q_\theta(z \mid x) \| q(z))],$$

聚合后验为 $q_\theta(z) = \int p_{\mathrm{data}}(x) q_\theta(z \mid x)\, dx$。

如果解码器类别无需使用 z 就能很好地建模数据，即含有接近 p_{data} 的某个 $p_\phi(x \mid z) = r(x)$，那么 ELBO 的一个最大化解取 $q_\theta(z \mid x) = p(z)$，从而 $I_q(x; z) = 0$ 且 $q_\theta(z) = p(z)$。这一“忽略 z”的解不会因网络加深而消失：

1. 学得编码变得与 x 无关，因而不携带可用于下游任务的、依赖数据的结构；

2. 对 z 施加条件或在其中移动不会影响生成样本，因而可控生成失效。

层次结构改变了什么？ HVAE 引入多个潜变量层次：

$$p_\phi(x, z_{1:L}) = p_\phi(x \mid z_1) \prod_{i=2}^{L} p_\phi(z_{i-1} \mid z_i) p(z_L),$$

ELBO 为

$$\begin{aligned}\mathcal{L}_{\mathrm{ELBO}}(x) = {} & \mathbb{E}_{q_\theta(z_1|x)}[\log p_\phi(x \mid z_1)] \\ & - \mathbb{E}_{q_\theta(z_{1:2}|x)}[\log q_\theta(z_1 \mid x) - \log p_\phi(z_1 \mid z_2)] \\ & - \sum_{i=2}^{L-1} \mathbb{E}_{q_\theta(z_{1:i+1}|x)}[\log q_\theta(z_i \mid z_{i-1}) - \log p_\phi(z_i \mid z_{i+1})] \\ & - \mathbb{E}_{q_\theta(z_{L-1}|x)}[D_{\mathrm{KL}}(q_\theta(z_L \mid z_{L-1}) \| p(z_L))].\end{aligned}$$

这里记 $\mathbb{E}_q := \mathbb{E}_{p_{\mathrm{data}}(x) q_\theta(z_{1:L}|x)}$。每个潜变量层次只与相邻层交互：编码器通过 $q_\theta(z_i \mid z_{i-1})$ 向上传递信息，解码器通过 $p_\phi(z_{i-1} \mid z_i)$ 向下传递信息。因此 ELBO 分解成重建项、相邻层匹配项和顶层先验 KL 正则化项。这些性质来自层次潜变量图，而不是简单加深扁平 VAE 的网络。

前方还有什么？ 虽然 HVAE 通过多个潜变量层提高表达能力，但其训练存在独特挑战。编码器和解码器必须联合优化，学习因而容易不稳定：较低层和解码器已经能够重建 x，留给高层潜变量的有效信号很少。到达更深变量的梯度往往间接且微弱，使它们难以作出有意义的贡献。另一个困难是平衡模型容量，因为表达能力过强的条件分布可能主导重建任务，抑制较高层潜变量的作用。

有趣的是，深分层的核心思想在变分扩散模型中获得更有力的实现，第 2.2 节将讨论它。扩散模型继承 HVAE 的渐进结构，又避开其核心弱点：固定编码过程，只学习生成方向的逆过程，从而提高稳定性和建模灵活性，并显著改善生成质量。

为简化记号，我们将在下文偏离编码器用 q、生成器用 p 的 VAE 常见约定，统一用 p 表示分布，并通过合适的下标或上标指定角色，在上下文中说明。

2.2 变分视角：DDPM

去噪扩散概率模型（DDPM）（Sohl-Dickstein et al., 2015; Ho et al., 2020）是扩散建模的基石。概念上与 VAE 和 HVAE 一样，它们在变分框架中工作，却引入了巧妙变化，处理前身的一些挑战。核心包含两个不同的随机过程：

- **正向过程（固定编码器）：** 通过转移核 $p(x_i \mid x_{i-1})$，分多步注入高斯噪声，逐渐污染数据。数据演化到各向同性高斯分布，实际上成为纯噪声。因此编码器是固定的，无需学习。

- **反向去噪过程（可学习解码器）：** 神经网络通过参数化分布 $p_\phi(x_{i-1} \mid x_i)$ 学习逆转噪声污染。从纯噪声出发，迭代去噪生成逼真样本。关键在于，单次去噪步骤比 VAE 经常尝试的从零生成完整样本更容易处理。

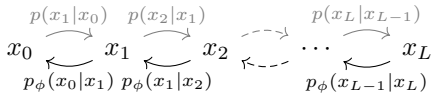


图 2.3: DDPM 示意图。固定正向过程（灰色）逐渐向数据加入高斯噪声，学得的反向过程逐步去噪生成新样本。来源：作者绘制；依原图重建。

通过固定编码器、将学习集中于渐进生成轨迹，DDPM 获得显著的稳定性和表达能力。本节聚焦 DDPM；更一般、更灵活的框架留到第 4.5 节介绍。

2.2.1 正向过程（固定编码器）

DDPM 的正向过程是固定且不可训练的操作，充当编码器。它分多步加噪，逐渐污染原始数据，最后将其变为简单先验分布 $p_{\text{prior}} := \mathcal{N}(0, I)$。图 2.3 的正向链和图 2.4 描述这一变换。下面形式化逐步退化过程。

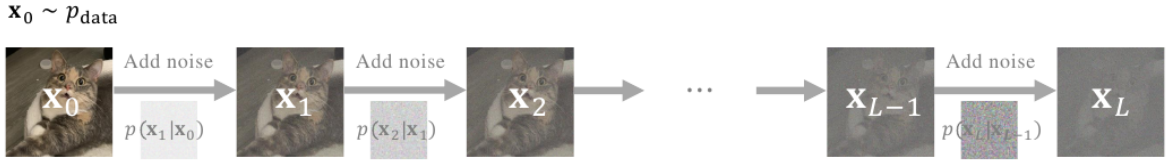


图 2.4: DDPM 正向过程示意图。逐步加入高斯噪声，将数据样本污染为纯噪声。图内 Add noise 表示 “加噪”。来源：作者绘制。

固定高斯转移。 正向过程每一步由固定高斯转移核控制：[3]

$$p(x_i \mid x_{i-1}) := \mathcal{N}\big(x_i; \sqrt{1-\beta_i^2}\, x_{i-1}, \beta_i^2 I\big).$$

过程从真实数据分布 p_{data} 抽取的 x_0 开始。$\{\beta_i\}_{i=1}^L$ 是预先确定、单调递增的噪声调度，每个 $\beta_i \in (0,1)$ 控制第 i 步注入的高斯噪声的方差。[4]方便起见，定义 $\alpha_i := \sqrt{1-\beta_i^2}$。这一数学定义恰好等价于直观迭代更新

$$x_i = \alpha_i x_{i-1} + \beta_i \epsilon_i,$$

其中 $\epsilon_i \sim \mathcal{N}(0, I)$ 独立同分布。即每一步先以 α_i 缩小前一状态 x_{i-1}，再加上由 β_i 缩放的受控高斯噪声。

扰动核与先验分布。 递归应用转移核，可以得到给定原数据 x_0 时第 i 步含噪样本分布的闭式表达：

$$p_i(x_i \mid x_0) = \mathcal{N}\big(x_i; \bar{\alpha}_i x_0, (1-\bar{\alpha}_i^2) I\big),$$
$$\bar{\alpha}_i := \prod_{k=1}^{i} \sqrt{1-\beta_k^2} = \prod_{k=1}^{i} \alpha_k.$$

[3]这种形式虽然外观可能不同，但在数学上等价于原始 DDPM 转移核。

[4]译注：按本书公式，β_i 是噪声标准差尺度，方差为 β_i^2；原文使用 “controls the variance”，并非将两者相等。

因此可以从 x_0 直接抽取 x_i：

$$x_i = \bar{\alpha}_i x_0 + \sqrt{1-\bar{\alpha}_i^2}\,\epsilon, \qquad \epsilon \sim \mathcal{N}(0, I). \tag{2.2.1}$$

若噪声调度 $\{\beta_i\}_{i=1}^L$ 是递增序列，则正向过程的分布收敛为

$$p_L(x_L \mid x_0) \longrightarrow \mathcal{N}(0, I), \qquad L \to \infty.$$

这促使我们选择与数据 x_0 无关的先验 $p_{\text{prior}} := \mathcal{N}(0, I)$。

2.2.2 反向去噪过程（可学习解码器）

DDPM 的核心能力是逆转正向扩散施加的受控退化。从纯粹、无结构的噪声 $x_L \sim p_{\text{prior}}$ 出发，目标是逐步去噪，直到出现协调、有意义的数据样本。这一反向生成通过 Markov 链进行，如图 2.5。根本挑战，也是引导 DDPM 发展的核心问题是：

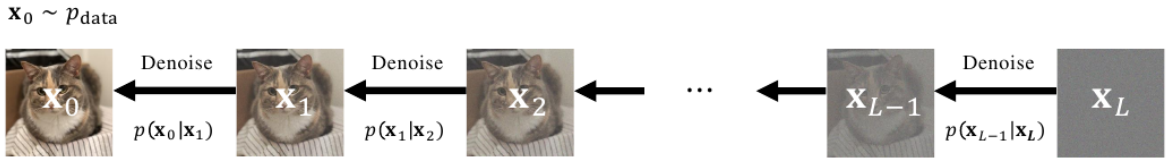


图 2.5: DDPM 反向（去噪）过程。从噪声 $x_L \sim p_{\text{prior}}$ 出发，按 $i = L, \ldots, 1$ 顺序抽取 $x_{i-1} \sim p(x_{i-1} \mid x_i)$，得到新生成的数据 x_0。真实转移 $p(x_{i-1} \mid x_i)$ 未知，我们希望近似它。Denoise 表示“去噪”。来源：作者绘制。

> **问题 2.2.1：** 能否精确计算，或至少有效近似反向转移核 $p(x_{i-1} \mid x_i)$，尤其是 $x_i \sim p_i(x_i)$ 分布复杂时?

我们不立即像 DDPM 原论文那样深入数学上复杂的 ELBO 推导（详见第 2.2.5 节），而先用更直观的方法：利用条件概率得到可计算表述。

概览：建模与训练目标。 要实现生成，目标是近似未知真实反向转移核 $p(x_{i-1} \mid x_i)$。引入可学习参数模型 $p_\phi(x_{i-1} \mid x_i)$，训练它最小化期望 KL 散度：

$$\mathbb{E}_{p_i(x_i)}[D_{\text{KL}}(p(x_{i-1} \mid x_i) \| p_\phi(x_{i-1} \mid x_i))]. \tag{2.2.2}$$

但是直接计算目标分布很困难。由 Bayes 定理，需计算

$$p(x_{i-1} \mid x_i) = p(x_i \mid x_{i-1}) \underbrace{\frac{p_{i-1}(x_{i-1})}{p_i(x_i)}}_{\text{难以计算}}.$$

边缘分布 $p_i(x_i)$ 和 $p_{i-1}(x_{i-1})$ 是对未知数据分布的期望：

$$p_i(x_i) = \int p_i(x_i \mid x_0) p_{\text{data}}(x_0)\, dx_0,$$

p_{i-1} 类似。由于 p_{data} 未知，这些积分没有可供计算的闭式表达；至多用样本近似，因此实际中无法获得精确密度。

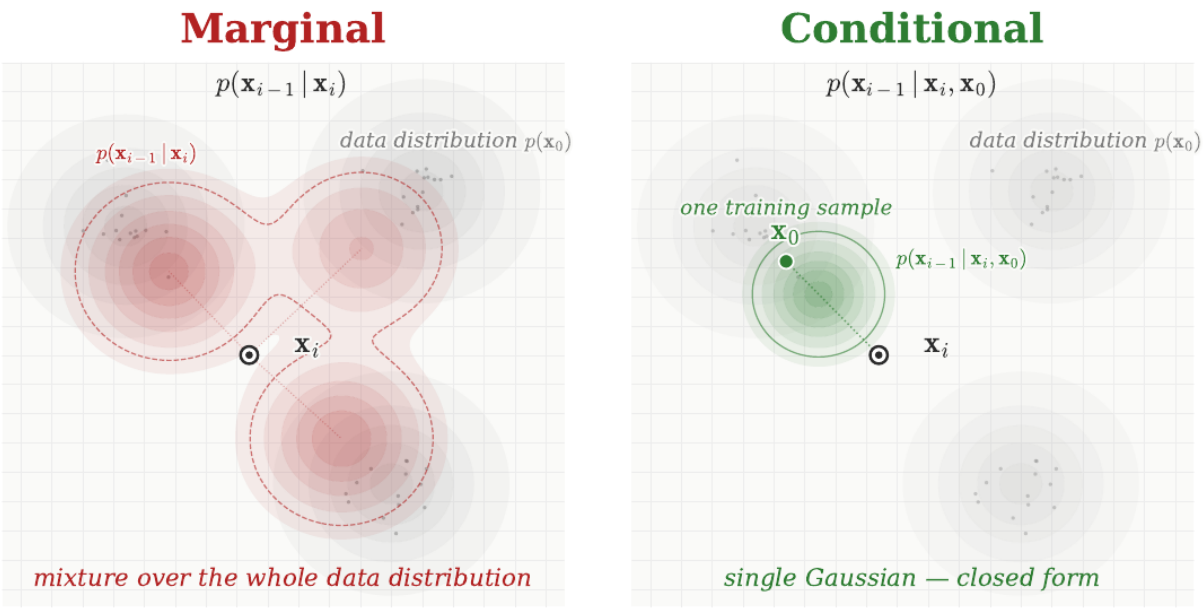


图 2.6: DDPM 的条件化技巧。左：固定含噪样本 x_i，反向分布 $p(x_{i-1} \mid x_i)$ 对所有可能产生 x_i 的干净样本 x_0 平均，因而可能是复杂混合分布。右：训练时知道生成 x_i 的干净样本 x_0；以它为条件得到 $p(x_{i-1} \mid x_i, x_0)$，其均值和方差均有高斯闭式表达，可用作简单回归目标。每个训练实例虽然只以一个干净样本为条件，但对所有样本平均后的条件训练目标，与直接学习边缘反向分布有相同最优模型，见定理 2.2.1。因此无需直接对由边缘混合诱导的、通常难以计算的复杂目标进行回归，也能学习相同的最优反向预测。图内 Marginal / Conditional 分别为“边缘 / 条件”，mixture over the whole data distribution 为“整个数据分布上的混合”，single Gaussian、closed form 为“单个高斯、闭式”。来源：作者借助 AI 辅助编程绘制。

通过条件化克服难计算性。 DDPM 的一个核心洞见是对干净数据样本 x_0 条件化，将难计算的反向核变成数学上可处理的核：

$$p(x_{i-1} \mid x_i, x_0) = p(x_i \mid x_{i-1}) \frac{p(x_{i-1} \mid x_0)}{p_i(x_i \mid x_0)}.$$

可计算性来自正向过程的两个性质：Markov 性给出 $p(x_i \mid x_{i-1}, x_0) = p(x_i \mid x_{i-1})$，而涉及的分布全为高斯。因此 $p(x_{i-1} \mid x_i, x_0)$ 也是高斯，有闭式表达（见式 (2.2.4)），图 2.6 将其可视化。关键在于，这一条件化策略导出的可计算目标，与式 (2.2.2) 看似难计算的边缘 KL 在优化意义上等价。

定理 2.2.1 (边缘与条件 KL 最小化的等价性)**.** *以下等式成立：*

$$\begin{aligned} &\mathbb{E}_{p_i(x_i)}[D_{\mathrm{KL}}(p(x_{i-1} \mid x_i) \| p_\phi(x_{i-1} \mid x_i))] \\ &\quad = \mathbb{E}_{p_{\mathrm{data}}(x_0)} \mathbb{E}_{p_i(x_i \mid x_0)}[D_{\mathrm{KL}}(p(x_{i-1} \mid x_i, x_0) \| p_\phi(x_{i-1} \mid x_i))] + C, \end{aligned} \tag{2.2.3}$$

其中 C 与 ϕ 无关。此外，式 (2.2.3) 的最小化解满足

$$p^*(x_{i-1} \mid x_i) = \mathbb{E}_{p(x_0 \mid x_i)}[p(x_{i-1} \mid x_i, x_0)] = p(x_{i-1} \mid x_i), \qquad x_i \sim p_i.$$

证明. 证明展开 KL 散度期望的定义，应用概率链式法则，并用对数恒等式将其分解为条件 KL 的期望与边缘 KL 之和。完整推导见附录 D.1.1 节。 □

这一通过条件化得到可计算目标的视角构成 DDPM 的基础，也揭示它与其他重要扩散模型的深刻共同点，第 3 章和第 5 章将继续讨论。最小化边缘分布间 KL 散度，与最小化特定条件分布间 KL 在数学上等价。后一形式特别有用，因为关键条件分布 $p(x_{i-1} \mid x_i, x)$ 有方便的闭式表达。

引理 2.2.2 (反向条件转移核)**.** $p(x_{i-1} \mid x_i, x)$ *为高斯分布：*

$$p(x_{i-1} \mid x_i, x) = \mathcal{N}(x_{i-1}; \mu(x_i, x, i), \sigma^2(i) I),$$

其中

$$\begin{aligned} \mu(x_i, x, i) &:= \frac{\bar{\alpha}_{i-1} \beta_i^2}{1 - \bar{\alpha}_i^2} x + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} x_i, \\ \sigma^2(i) &:= \frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2} \beta_i^2. \end{aligned} \tag{2.2.4}$$

后文引理 4.5.2 将给出超出式 (2.2.1) 的 DDPM 加噪过程的更一般公式。

2.2.3 反向转移核 $p_\phi(x_{i-1} \mid x_i)$ 的建模

利用定理 2.2.1 的梯度层面等价性，以及引理 2.2.2 的高斯反向条件分布，DDPM 假设每个反向转移均为高斯：

$$p_\phi(x_{i-1} \mid x_i) := \mathcal{N}(x_{i-1}; \mu_\phi(x_i, i), \sigma^2(i) I), \tag{2.2.5}$$

其中 $\mu_\phi(\cdot, i) : \mathbb{R}^D \to \mathbb{R}^D$ 为可学习均值函数，$\sigma^2(i) > 0$ 固定为式 (2.2.4) 的值。[5] 记对各时间步求和、给定数据 $x_0 \sim p_{\text{data}}$ 的 KL 目标为

$$\mathcal{L}_{\text{diffusion}}(x_0; \phi) := \sum_{i=2}^{L} \mathbb{E}_{p_i(x_i|x_0)}[D_{\text{KL}}(p(x_{i-1} \mid x_i, x_0) \| p_\phi(x_{i-1} \mid x_i))]. \tag{2.2.6}$$

两者均为高斯，且采用式 (2.2.5) 的参数化，因此目标有闭式表达，简化为

$$\mathcal{L}_{\text{diffusion}}(x_0; \phi) = \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{p_i(x_i|x_0)}[\|\mu_\phi(x_i, i) - \mu(x_i, x_0, i)\|_2^2] + C, \tag{2.2.7}$$

C 与 ϕ 无关。再对数据分布平均，去掉不影响优化的常数 C，最终 DDPM 训练目标为

$$\mathcal{L}_{\text{DDPM}}(\phi) := \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{x_0} \mathbb{E}_{p_i(x_i|x_0)}[\|\mu_\phi(x_i, i) - \mu(x_i, x_0, i)\|_2^2], \tag{2.2.8}$$

其中 $x_0 \sim p_{\text{data}}$。

正向扰动核 $p_i(x_i \mid x_0)$ 在训练目标中有重要计算作用。它给出干净样本经过 i 个正向步骤后含噪状态的分布。由于每个正向转移都是线性高斯，其复合也有闭式高斯分布，见式 (2.2.1) 附近的讨论。因此选定 i 后，可以从 x_0 直接抽取 $x_i \sim p_i(x_i \mid x_0)$，无需先生成中间状态 $x_1, \ldots, x_{i-1}$。每个损失项只用干净样本、选定时间步和直接污染的样本即可估计，使随机训练在计算上高效。

2.2.4 预测与损失的实际选择

ϵ 预测。 典型 DDPM 实现并不直接使用式 (2.2.8) 基于均值预测参数化的原始损失，而采用等价的重参数化，即 ϵ 预测（噪声预测）。回忆噪声水平 i 的含噪样本由下式生成：

$$x_i = \bar{\alpha}_i x_0 + \sqrt{1 - \bar{\alpha}_i^2}\epsilon, \qquad x_0 \sim p_{\text{data}}, \qquad \epsilon \sim \mathcal{N}(0, I). \tag{2.2.9}$$

据此，式 (2.2.4) 的反向均值可重写为

$$\mu(x_i, x_0, i) = \frac{1}{\alpha_i}\left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}}\epsilon\right).$$

因此可用直接预测噪声的神经网络 $\epsilon_\phi(x_i, i)$ 参数化模型均值：

$$\mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \underbrace{\epsilon_\phi(x_i, i)}_{\epsilon\text{预测}}\right).$$

代入原始损失，得到预测噪声与真实噪声之间的平方 ℓ_2 误差：

$$\|\mu_\phi(x_i, i) - \mu(x_i, x_0, i)\|_2^2 \propto \|\epsilon_\phi(x_i, i) - \epsilon\|_2^2,$$

比例系数依赖 i。直观地，模型充当“噪声侦探”，估计正向过程每一步加入的随机噪声。从污染样本中减去这个估计会使其更接近干净原样本，逐步重复即可从纯噪声重建数据。

[5] 译注：当 $i = 1$ 时，按 $\bar{\alpha}_0 = 1$，该式给出 $\sigma^2(1) = 0$。正方差高斯及后续 KL 回归式应用于 $i \geq 2$；最末重建步骤的 $p_\phi(x_0 \mid x_1)$ 需要另行指定，见式 (2.2.13)。原文在此未明确区分边界。

ϵ 预测的简化损失。 实践中进一步省略加权项，得到广泛使用的 DDPM 训练损失：

$$\mathcal{L}_{\text{simple}}(\phi) := \mathbb{E}_i \mathbb{E}_{x\sim p_{\text{data}}(x)} \mathbb{E}_{\epsilon\sim\mathcal{N}(0,I)}[\|\epsilon_\phi(x_i, i) - \epsilon\|_2^2], \tag{2.2.10}$$

其中 $x_i = \bar{\alpha}_i x_0 + \sqrt{1-\bar{\alpha}_i^2}\epsilon$, $x_0 \sim p_{\text{data}}$。由于每个时间步 t 的目标噪声都有单位方差，式 (2.2.10) 的 ℓ_2 损失在不同 t 保持一致尺度。这避免目标消失或爆炸，并免去显式损失加权。

$\mathcal{L}_{\text{DDPM}}$ 与 $\mathcal{L}_{\text{simple}}$ 有相同最优解 ϵ^*，因为式 (2.2.10) 本质上是最小二乘问题（与后文命题 4.3.1 或 6.3.1 相似）：[6]

$$\epsilon^*(x_i, i) = \mathbb{E}[\epsilon \mid x_i], \qquad\qquad x_i \sim p_i.$$

噪声预测网络估计产生 x_i 时正向过程加入的噪声。达到最优时，即使 x_i 并不唯一确定原始干净样本，估计仍等于真实噪声的条件期望。

另一等价参数化：x 预测。 式 (2.2.4) 启发另一等价参数化，即 x 预测（干净数据预测）：神经网络 $x_\phi(x_i, i)$ 根据噪声水平 i 的含噪输入 $x_i \sim p_i(x_i)$ 预测干净（去噪）样本。将反向均值中的真实 x_0 换成 $x_\phi(x_i, i)$，得到

$$\mu_\phi(x_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2} x_\phi(x_i, i) + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2} x_i.$$

与噪声预测类似，训练目标可写成

$$\|\mu_\phi(x_i, i) - \mu(x_i, x_0, i)\|_2^2 \propto \|x_\phi(x_i, i) - x_0\|_2^2, \qquad\qquad x_0 \sim p_{\text{data}},$$

即根据含噪版本预测原数据。式 (2.2.8) 的均值匹配损失由此化为

$$\mathbb{E}_i \mathbb{E}_{x_0\sim p_{\text{data}}} \mathbb{E}_{\epsilon\sim\mathcal{N}(0,I)}[\omega_i \|x_\phi(x_i, i) - x_0\|_2^2],$$

ω_i 是某个权重函数。最小二乘问题的最优解为（见命题 4.3.1 或 6.3.1）

$$x^*(x_i, i) = \mathbb{E}[x_0 \mid x_i], \qquad\qquad x_i \sim p_i. \tag{2.2.11}$$

即给定时间步 i 的含噪观测 x_i，模型应预测干净数据的期望。x 预测与 ϵ 预测在数学上等价，由正向过程联系：

$$x_i = \bar{\alpha}_i x_\phi(x_i, i) + \sqrt{1-\bar{\alpha}_i^2}\epsilon_\phi(x_i, i). \tag{2.2.12}$$

可以预测干净样本，也可以预测噪声，使二者按正向加噪系数组合后重现 x_i。

2.2.5 DDPM 的 ELBO

按式 (2.2.5) 定义反向转移，DDPM 联合生成分布为

$$p_\phi(x_0, x_{1:L}) := p_\phi(x_0 \mid x_1) p_\phi(x_1 \mid x_2) \cdots p_\phi(x_{L-1} \mid x_L) p_{\text{prior}}(x_L),$$

[6] 去掉 $\mathcal{L}_{\text{DDPM}}$ 中由 ELBO 导出的权重会改变训练目标，但不改变总体最优预测 $\epsilon^*(x_i, i) = \mathbb{E}[\epsilon \mid x_i]$。因此，加权损失与简化损失具有相同理想预测器，却在训练时侧重不同噪声水平。实践中权重仍可影响优化与性能。

数据的边缘生成模型为

$$p_\phi(x_0) := \int p_\phi(x_0, x_{1:L})\, dx_{1:L}.$$

式 (2.2.6) 的 DDPM 训练可以严格奠基于最大似然估计 (式 (1.1.2))。与第 2.1 节 VAE 和 HVAE 类似，其目标形成对数密度下界 ELBO。

定理 2.2.3 (DDPM 的 ELBO)**.**

$$\begin{aligned} -\log p_\phi(x_0) &\le -\mathcal{L}_{\text{ELBO}}(x_0;\phi) \\ &:= \mathcal{L}_{\text{prior}}(x_0) + \mathcal{L}_{\text{recon.}}(x_0;\phi) + \mathcal{L}_{\text{diffusion}}(x_0;\phi), \end{aligned} \tag{2.2.13}$$

其中各损失为

$$\begin{aligned} \mathcal{L}_{\text{prior}}(x_0) &:= D_{\text{KL}}(p(x_L \mid x_0) \| p_{\text{prior}}(x_L)), \\ \mathcal{L}_{\text{recon.}}(x_0;\phi) &:= \mathbb{E}_{p(x_1|x_0)}[-\log p_\phi(x_0 \mid x_1)], \\ \mathcal{L}_{\text{diffusion}}(x_0;\phi) &= \sum_{i=2}^{L} \mathbb{E}_{p_i(x_i|x_0)}[D_{\text{KL}}(p(x_{i-1} \mid x_i, x_0) \| p_\phi(x_{i-1} \mid x_i))]. \end{aligned}$$

证明. 与 HVAE / VAE 的 ELBO 式 (2.1.3) 一样，推导应用 Jensen 不等式，再作简化。详见附录 D.1.2 节。 □

ELBO 由三项组成：

- 选择噪声调度 $\{\beta_i\}$ 使 $p(\cdot \mid x_0) \approx p_{\text{prior}}(\cdot)$，可使 $\mathcal{L}_{\text{prior}}$ 忽略不计。
- $\mathcal{L}_{\text{recon.}}$ 可通过 Monte Carlo 估计近似并优化，实际实现见 Ho et al. (2020)、Kingma et al. (2021)。
- $\mathcal{L}_{\text{diffusion}}$（式 (2.2.6)）在所有步骤 i 将反向条件分布 $p_\phi(x_{i-1} \mid x_i)$ 匹配到 $p(x_{i-1} \mid x_i)$。

还可像式 (2.1.2) 那样，以 $z = x_{1:L}$ 为潜变量，从数据处理不等式解释 ELBO：

$$D_{\text{KL}}(p_{\text{data}}(x_0) \| p_\phi(x_0)) \le D_{\text{KL}}(p(x_0, x_{1:L}) \| p_\phi(x_0, x_{1:L})),$$

其中 $p(x_0, x_{1:L}) := p_{\text{data}}(x_0) p(x_1 \mid x_0) \cdots p(x_L \mid x_{L-1})$ 是正向过程的联合分布。

注。 扩散的变分视角与层次潜变量图景特别契合：“编码器”就是固定正向加噪链，没有要学习的推断网络。尽管如此，ELBO 仍分解为逐步 KL 项，以及式 (2.2.13) 的终端先验项和重建项。DDPM 训练特别易于处理，是因为在线性高斯正向过程下，这些逐步 KL 项可重写为具有闭式条件目标的简单去噪回归。因此，关键简化并不是没有逐层 KL 项，而是固定正向过程将它们化为可高效采样的监督去噪目标。

2.2.6 采样

训练好噪声预测模型 $\epsilon_{\phi^\times}(x_i, i)$ 后，[7]按图 2.5 顺序采样，以参数化转移 $p_{\phi^\times}(x_{i-1} \mid x_i)$ 代替真实转移。具体地，从随机种子 $x_L \sim p_{\text{prior}} = \mathcal{N}(0, I)$ 出发，对 $i = L, L-1, \ldots, 1$，递归按下式采样：

$$x_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i}\left(x_i - \frac{1-\alpha_i^2}{\sqrt{1-\bar{\alpha}_i^2}}\epsilon_{\phi^\times}(x_i, i)\right)}_{\mu_{\phi^\times}(x_i, i)} + \sigma(i)\epsilon_i, \qquad \epsilon_i \sim \mathcal{N}(0, I). \tag{2.2.14}$$

这一“去噪”过程持续到得到最终干净生成样本 x_0。

DDPM 采样的另一种解释。 把更新重写，使噪声水平结构显式可见，会得到有用解释。由式 (2.2.12)，预测噪声可由当前样本和预测干净样本表示：

$$\epsilon_{\phi^\times}(x_i, i) = \frac{x_i - \bar{\alpha}_i x_{\phi^\times}(x_i, i)}{\sqrt{1-\bar{\alpha}_i^2}}.$$

代入式 (2.2.14) 并整理，得到

$$x_{i-1} \leftarrow \bar{\alpha}_{i-1} x_{\phi^\times}(x_i, i) + \underbrace{\sqrt{1-\bar{\alpha}_{i-1}^2 - \widetilde{\beta}_i^2}\,\epsilon_{\phi^\times}(x_i, i)}_{\text{原文标为合并标准差}\sqrt{1-\bar{\alpha}_{i-1}^2}} + \widetilde{\beta}_i \epsilon_i. \tag{2.2.15}$$

其中 DDPM 后验方差为[8]

$$\widetilde{\beta}_i^2 = \frac{(1-\bar{\alpha}_{i-1}^2)(1-\alpha_i^2)}{1-\bar{\alpha}_i^2}.$$

残差系数还满足

$$(1-\bar{\alpha}_{i-1}^2 - \widetilde{\beta}_i^2) + \widetilde{\beta}_i^2 = 1 - \bar{\alpha}_{i-1}^2,$$

所以更新具有与 $i-1$ 水平正向边缘相同的噪声水平结构。这回到了式 (1.4.1) 的初步操作模板：预测干净部分，再将样本重写到更低噪声水平。DDPM 以随机方式完成重写，将由 x_i 估计的噪声方向与新高斯噪声组合。确定性采样器遵循同一基本思想，但去掉新随机性，相应调整剩余噪声系数。第 9.2 节系统研究扩散采样器时将重访这一构造。

比较式 (2.2.15) 与正向边缘 $x_{i-1} = \bar{\alpha}_{i-1} x_0 + \sqrt{1-\bar{\alpha}_{i-1}^2}\,\bar{\epsilon}$，结构相同：信号系数 $\bar{\alpha}_{i-1}$，噪声标准差 $\sqrt{1-\bar{\alpha}_{i-1}^2}$，只是未知 x_0 被网络预测 $x_{\phi^\times}(x_i, i)$ 代替。换言之，每一步先预测干净数据，再重新加噪到恰好 $i-1$ 的噪声水平。因此可以把 DDPM 采样看成反复执行两个操作：

1. **去噪：** 从当前含噪输入 x_i 估计干净数据 $x_{\phi^\times}(x_i, i)$；
2. **重新加噪：** 按式 (2.2.15) 加回降低到 $i-1$ 水平的噪声，产生噪声水平与正向过程第 $i-1$ 步匹配的 x_{i-1}。

[7]用符号 $\times$ 表示模型已经训练完毕并冻结。

[8]系数 $\sqrt{1-\bar{\alpha}_{i-1}^2 - \widetilde{\beta}_i^2}$ 简化为 $\alpha_i(1-\bar{\alpha}_{i-1}^2)/\sqrt{1-\bar{\alpha}_i^2}$，始终非负，所以平方根定义良好。

译注：上述“合并标准差”和“恰好匹配噪声水平”的说法是原文的操作性解释。$\epsilon_{\phi^\times}(x_i, i)$ 给定 x_i 后是确定性预测，一般并非独立标准高斯变量；系数平方和恒等式本身并不保证更新残差有该高斯标准差，也不保证有限步高斯反向近似精确恢复真实边缘。保留原式与原解释，区分系数结构和实际分布。

即使 $x_{\phi^\times}$ 被训练为最优去噪器，即式 (2.2.11) 的条件期望最小化解，也只能预测给定 x_i 后的平均干净样本。这会导致模糊预测，尤其在高噪声水平，难以从严重污染输入恢复详细结构。从这一视角，扩散采样从高噪声走向低噪声，逐渐细化干净信号的估计。早期步骤确立全局结构，后期添加细节，噪声消除时样本逐渐逼真。

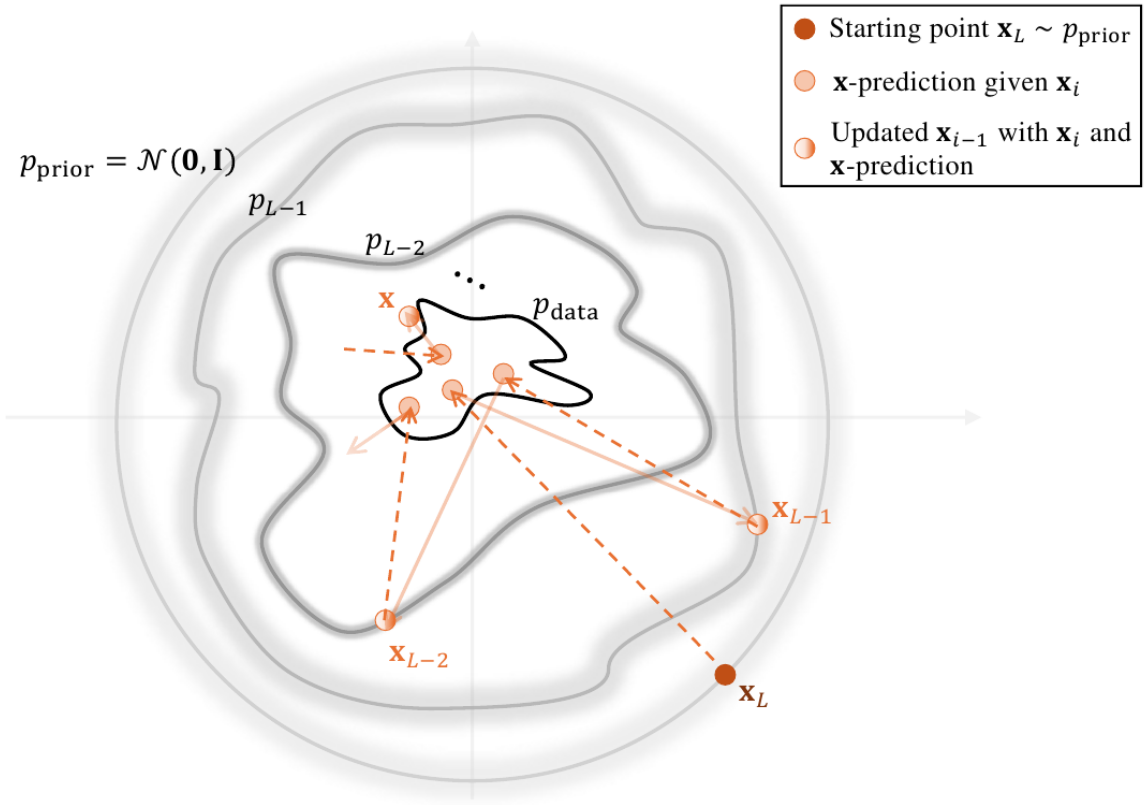


图 2.7: DDPM 采样的“先去噪、再加噪”图景。从当前含噪样本 x_i 先估计底层干净信号 $x_{\phi^\times}(x_i, i)$，再将估计重新加噪到第 $i-1$ 噪声水平，采得噪声更少的 x_{i-1}。图例依次是起点 $x_L \sim p_{\text{prior}}$、给定 x_i 的 x 预测、利用 x_i 和 x 预测更新的 x_{i-1}。来源：作者绘制。

DDPM 的缓慢采样。 DDPM（即扩散模型）的采样本来就慢。原始表述和实现通常需要约 1000 个去噪步骤才能生成一个样本，因为它通过一长串小修正进行：每一步把当前含噪样本向更干净的方向略作更新，下次更新必须从上次结果开始。因此标准 DDPM 采样是时间步进且高度顺序化的；高质量通常需要许多步骤紧密跟随反向扩散路径。

定理 2.2.1 说明，表达能力足够的 $p_\phi(x_{i-1} \mid x_i)$ 理论上可以匹配真实反向分布。然而实践中通常用高斯模型近似，限制了表达能力。正向噪声尺度 β_i 小时，真实反向分布近似高斯，能够准确近似；β_i 大时，则引入单个高斯无法捕捉的多峰或强非高斯性。为维持精度，DDPM 使用许多小 β_i 步骤，组成顺序链，每一步都依赖前一步并需要一次神经网络求值 $\epsilon_{\phi^\times}(x_i, i)$。这造成 $O(L)$ 次顺序计算，阻碍并行化，降低生成速度。

第 4 章将从微分方程问题出发，更有原则地解释这一内在采样瓶颈，并由此引出加速生成的连续时间数值策略。

2.3 结束语

本章从变分视角追溯扩散模型的起源。我们从基础生成模型 VAE 开始，它通过证据下界 ELBO 学习数据与结构化潜在空间之间的概率映射。HVAE 通过堆叠潜变量层扩展这一思想，引入渐进的、从粗到细的生成概念，但仍面临训练稳定性和样本质量的挑战。

随后，我们将 DDPM 视为变分框架中的关键演进。把编码器固定为渐进加噪过程，只学习反向去噪步骤，使它避开 HVAE 的训练不稳定性。关键是，DDPM 同样通过最大化对数似然的变分界训练，目标分解成一系列简单去噪任务。可计算性来自强有力的条件化策略：把难计算的边缘目标变成可处理的条件目标。这一主题会在扩散模型中反复出现。

虽然变分框架为 DDPM 提供完整有力的基础，它并非唯一理解方式。基于能量的建模原理给出另一个同样基础的视角。下一章将探索得分视角：

1. 将焦点从学习去噪转移概率 $p_\phi(x_{i-1} \mid x_i)$，转向直接学习数据对数密度的梯度，即得分函数；

2. 说明这一源于 EBM 的方法如何产生噪声条件得分网络（NCSN），并揭示 DDPM 学得的噪声预测与得分函数之间深刻的数学等价性。

这一视角将提供新洞见，并成为后续统一连续时间框架的另一基石。

第三章　得分视角：从 EBM 到 NCSN

前几章从变分起源追溯扩散模型，展示了它如何产生于 VAE 框架。现在转向第二个同样基础的视角：基于能量的模型（EBM）（Ackley et al., 1985; LeCun et al., 2006）。EBM 用能量景观表示分布，在数据处能量低，在其他位置能量高。采样通常依靠 Langevin 动力学，沿景观梯度将样本移向高密度区域。这一称为得分的梯度场指向概率更高的方向。[1]

核心观察是，仅知道得分就足以生成：它使样本移向更可能出现的区域，无需计算难以处理的归一化常数。基于得分的扩散模型直接建立于此。它们不只关注干净数据分布，而考虑一系列受高斯噪声扰动的分布，其得分更易近似。学习这些得分得到一族向量场，逐步引导含噪样本返回数据，使生成成为渐进去噪。

学完本章后，你将能够：

- 理解得分建模的核心思想：什么是得分函数，以及如何结合 Langevin 动力学用于生成；
- 理解去噪得分匹配如何用条件化技巧学习单个噪声水平的得分，以及 Tweedie 公式如何联系得分预测与去噪；
- 理解噪声条件得分网络（NCSN）如何将去噪得分匹配扩展到多个噪声水平、多个水平为何有用，以及 NCSN 得分预测如何联系 DDPM 噪声预测。

阅读路线。　熟悉 EBM 的读者可以略读第 3.1 节，从第 3.2.1 节开始。

3.1　基于能量的模型

对熟悉 EBM 的读者，本节可作为简短回顾，并搭建通往扩散得分视角的桥梁。

3.1.1　用能量函数建模概率分布

令 $x \in \mathbb{R}^D$ 表示数据点。EBM 通过参数为 ϕ 的能量函数 $E_\phi(x)$ 定义概率密度，为更可能出现的构型赋予更低能量。分布为

$$p_\phi(x) := \frac{\exp(-E_\phi(x))}{Z_\phi}, \qquad Z_\phi := \int_{\mathbb{R}^D} \exp(-E_\phi(x))\, dx,$$

其中 Z_ϕ 称为配分函数，保证归一化 $\int_{\mathbb{R}^D} p_\phi(x)\, dx = 1$。在这个图景中，较低能量对应较高概率，

[1] 译注：这里的得分是对数密度的梯度，即能量的负梯度；“沿景观梯度”应依下文公式理解为沿能量下降方向。

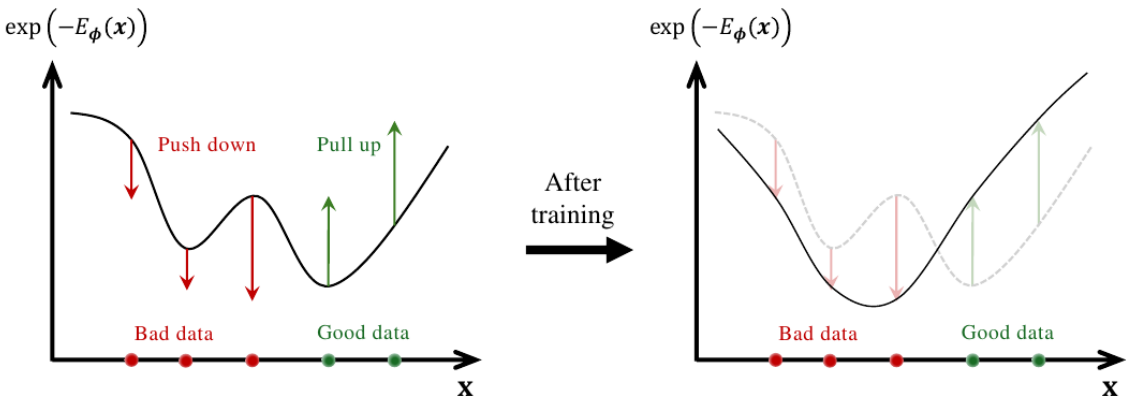


图 3.1: EBM 训练示意图。模型在“坏”数据处降低密度（提高能量，红色箭头），在“好”数据处提高密度（降低能量，绿色箭头）。图中 Push down、Pull up、After training 分别为“压低”“拉高”“训练后”，Bad data / Good data 为“坏 / 好数据”；纵轴为未归一化密度 $\exp(-E_\phi(x))$。来源：作者绘制。

就像小球滚入谷底。配分函数保证所有概率加起来为一，因此只有能量相对值有意义。例如，给所有能量加同一常数，会使分子和分母乘以相同因子，分布不变。

此外，由于配分函数强制归一化，在一个区域降低能量会增加其概率，其补集的概率相应减小。因此 EBM 遵守严格的全局权衡：使一个谷更深，必然使其他谷相对更浅；概率质量在整个空间重新分配，而不是独立赋予每个区域。

EBM 最大似然训练的挑战。 原则上，EBM 可以通过最大似然训练，自然平衡数据拟合与全局正则化（式 (1.1.2)）：

$$\begin{aligned}\mathcal{L}_{\mathrm{MLE}}(\phi) &= \mathbb{E}_{p_{\mathrm{data}}(x)}\left[\log \frac{\exp(-E_\phi(x))}{Z_\phi}\right] \\ &= -\underbrace{\mathbb{E}_{p_{\mathrm{data}}}[E_\phi(x)]}_{\text{降低数据能量}} - \underbrace{\log \int \exp(-E_\phi(x))\,dx}_{\text{全局正则化}},\end{aligned} \tag{3.1.1}$$

其中 $Z_\phi = \int \exp(-E_\phi(x))\,dx$。第一项降低真实数据的能量，第二项通过配分函数强制归一化。但高维时计算 $\log Z_\phi$ 及其梯度很困难，因为需要对模型分布取期望。这促使我们考虑替代目标：对比散度（Hinton, 2002）等方法近似该项，得分匹配则完全绕开它。

下面先在第 3.1.2 节介绍得分函数，第 3.1.3 节给出绕开配分函数的可计算得分匹配目标，再在第 3.1.4 节讨论利用得分函数的实用采样方法 Langevin 动力学。

3.1.2 动机：什么是得分？

对于 $\mathbb{R}^D$ 上的密度 $p(x)$，得分函数是对数密度的梯度：

$$s(x) := \nabla_x \log p(x), \qquad\qquad s : \mathbb{R}^D \to \mathbb{R}^D.$$

直观地，得分形成指向更高概率区域的向量场，提供一个局部指引，说明数据最可能出现在哪里（图 3.2）。

为什么建模得分而不是密度？ 这样做有理论和实际好处。

1. **不受归一化常数束缚**。许多分布由未归一化密度 $\widetilde{p}(x)$ 给定，如 EBM 的 $\exp(-E_\phi(x))$：

$$p(x) = \frac{\widetilde{p}(x)}{Z}, \qquad Z = \int \widetilde{p}(x)\, dx.$$

虽然 Z 难计算，得分却只依赖 $\widetilde{p}$：

$$\nabla_x \log p(x) = \nabla_x \log \widetilde{p}(x) - \underbrace{\nabla_x \log Z}_{=0} = \nabla_x \log \widetilde{p}(x), \tag{3.1.2}$$

因为 Z 不依赖 x，因此完全绕开配分函数。

2. **完整的表示**。得分函数完全刻画底层分布。由于它是对数密度梯度，可以恢复密度到一个常数因子：

$$\log p(x) = \log p(x_0) + \int_0^1 s(x_0 + t(x - x_0))^\top (x - x_0)\, dt,$$

x_0 为参考点，$\log p(x_0)$ 由归一化固定。因此，建模得分与建模密度本身同样有表达力，又往往更适于生成建模。[2]

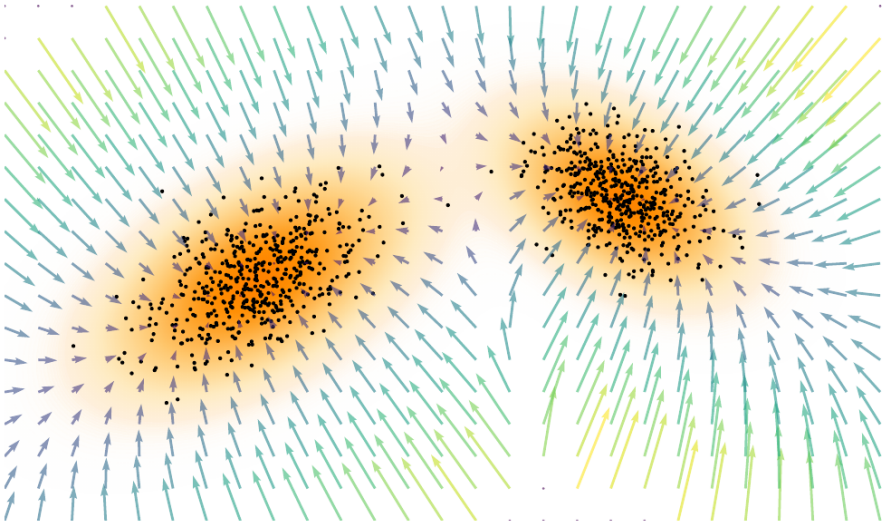


图 3.2: 得分向量场示意图。$\nabla_x \log p(x)$ 指向密度增加的方向。来源：作者绘制。

3.1.3 通过得分匹配训练 EBM

EBM 的密度为 $p_\phi(x) = \exp(-E_\phi(x))/Z_\phi$。最大似然训练需要计算通常难处理的 Z_ϕ。关键观察是，模型得分简化为 $-\nabla_x E_\phi(x)$，与 Z_ϕ 无关，见式 (3.1.2)。

得分匹配（Hyvärinen and Dayan, 2005）利用得分只依赖能量函数这一事实。不拟合归一化概率，而通过对齐模型得分与未知的数据得分训练 EBM：

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \tfrac{1}{2}\mathbb{E}_{p_{\mathrm{data}}(x)}[\|\nabla_x \log p_\phi(x) - \nabla_x \log p_{\mathrm{data}}(x)\|_2^2]. \tag{3.1.3}$$

[2]译注：这里的线段积分要求该路径上对数密度可微；从得分确定整个分布还需支集连通及相应正则性等条件。分离支集各分量的相对质量一般不能由分量内得分确定，与首章所记 Fisher 散度疑点相同。

虽然数据得分不可访问，分部积分可得到仅涉及能量及其导数的等价表达（详见后文命题 3.2.1）：

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \mathbb{E}_{p_{\mathrm{data}}(x)}[-\operatorname{Tr}(\nabla_x^2 E_\phi(x)) + \tfrac{1}{2}\|\nabla_x E_\phi(x)\|_2^2] + C,$$

其中 $\nabla_x^2 E_\phi(x)$ 是 Hessian，C 与 ϕ 无关。

这个表述消除配分函数，训练中无需从模型采样。主要缺点是需要二阶导数：虽然只要 Hessian 的迹 $\operatorname{Tr}(\nabla_x^2 E_\phi)$，而非完整矩阵，但精确计算通常仍需汇集输入各坐标的二阶导数信息，代价一般随输入维数 D 增大。本章稍后将再讨论解决办法。

3.1.4 使用得分函数的 Langevin 采样

由能量函数 $E_\phi(x)$ 定义的 EBM 可用 Langevin 动力学采样。先给离散时间更新，再给作为随机微分方程（SDE）的连续时间极限，最后讨论其探索复杂能量景观的物理直觉。

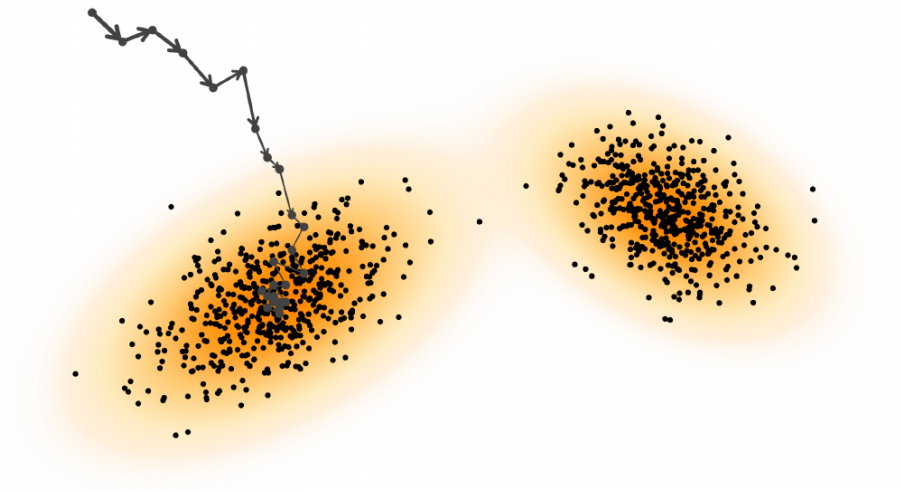


图 3.3: Langevin 采样示意。通过式 (3.1.5) 的更新，用得分函数 $\nabla_x \log p_\phi(x)$ 引导轨迹朝向高密度区域，箭头表示该更新。来源：作者绘制。

离散时间 Langevin 动力学。 更新为

$$x_{n+1} = x_n - \eta \nabla_x E_\phi(x_n) + \sqrt{2\eta}\epsilon_n, \qquad n = 0, 1, 2, \ldots, \tag{3.1.4}$$

其中 x_0 从某个分布（常为高斯）初始化，$\eta > 0$ 是步长，$\epsilon_n \sim \mathcal{N}(0, I)$ 是高斯噪声。噪声加入随机性，使系统可探索局部极小值以外的区域。因为得分为 $\nabla_x \log p_\phi(x) = -\nabla_x E_\phi(x)$，等价地有

$$x_{n+1} = x_n + \eta \nabla_x \log p_\phi(x_n) + \sqrt{2\eta}\epsilon_n. \tag{3.1.5}$$

得分引导样本移向高密度区域，这一形式是扩散模型的核心，后文会详述。

连续时间 Langevin 动力学。 步长 $\eta \to 0$ 时，离散更新自然收敛到由 Langevin SDE 描述的连续时间过程：[3]

$$dx(t) = \nabla_x \log p_\phi(x(t))\, dt + \sqrt{2}\, dw(t), \tag{3.1.6}$$

其中 $w(t)$ 是标准 Brownian 运动，也称 Wiener 过程。[4]应当理解，式 (3.1.4) 是这一连续 SDE 的 Euler–Maruyama 离散化。

在标准正则性假设下，例如 $p_\phi \propto e^{-E_\phi}$ 且 E_ϕ 具有约束性、足够光滑，$x(t)$ 的分布在 $t \to \infty$ 时（指数快速地）收敛于 p_ϕ；因此可以模拟（求解）式 (3.1.6) 来采样。[5]

为什么使用 Langevin 采样？ 从物理视角很容易理解它：能量函数定义势能景观，决定粒子行为。按原文所称的 Newton 动力学，由该能量导出的力场作用下粒子运动由 ODE 描述：

$$dx(t) = -\nabla_x E_\phi(x(t))\, dt.$$

它确定性地驱动粒子沿坡下降到局部能量极小值。但确定性动力学可能困在局部极小值，不能探索完整数据分布。[6]

为克服这一局限，Langevin 动力学引入随机扰动，得到 SDE

$$dx(t) = -\nabla_x E_\phi(x(t))\, dt + \underbrace{\sqrt{2}\, dw(t)}_{\text{注入噪声}},$$

其中 $w(t)$ 是标准 Brownian 运动。噪声让粒子跨越能垒、逃离局部极小值，使轨迹成为随机过程，其平稳分布趋于 Boltzmann 分布

$$p_\phi(x) \propto e^{-E_\phi(x)}.$$

从这个视角，EBM 学习推动样本走向高概率区域的力场。Langevin 采样对 EBM 特别有用，因为它无需显式计算配分函数，就提供了从模型分布生成样本的实用途径。迭代 Langevin 更新可得到近似目标分布的样本。

Langevin 采样的固有挑战。 作为广泛使用的 MCMC 采样器，Langevin 动力学在高维空间有严重局限。效率高度敏感于步长 η、噪声尺度和准确近似目标分布所需的迭代次数。

低效的核心是较差的“混合时间”：有许多孤立模式的复杂数据分布中，Langevin 采样从一个高概率区域转移到另一个区域往往极其耗时。维数增大时问题明显恶化，收敛可能慢到无法接受。

---

[3]因子 $\sqrt{2}$ 使 Langevin 动力学保持 p_ϕ 不随时间改变，即它是平稳分布：若 $x(0) \sim p_\phi$，则所有 $t \geq 0$ 都有 $x(t) \sim p_\phi$。等价地，它是 Fokker–Planck 方程 $\partial_t \rho = -\nabla \cdot (\rho \nabla \log p_\phi) + (\sigma^2/2)\Delta\rho$ 的平稳解（见附录 B）。代入 $\rho = p_\phi$ 得 $(\sigma^2/2 - 1)\Delta p_\phi = 0$，原文据此要求 $\sigma = \sqrt{2}$。

[4]Brownian 增量满足 $w(t+\eta) - w(t) \sim \mathcal{N}(0, \eta I)$。Euler–Maruyama 步进噪声因而为 $\sqrt{2}[w(t+\eta) - w(t)] = \sqrt{2\eta}\epsilon_n$，$\epsilon_n \sim \mathcal{N}(0, I)$，解释了 $\sqrt{\eta}$ 因子；这是平方根缩放的来源。Brownian 运动和 SDE 的详细介绍见附录 A。

[5]译注：存在平稳密度、趋近平衡和指数收敛是不同层次的结论。足够光滑且有约束性本身并非一般的指数速率保证，还需相应遍历性、谱隙或更具体的条件。有限步 Euler–Maruyama 通常还存在离散化误差。保留原文概述，不将其视为无条件收敛定理。

[6]译注：这里是一阶过阻尼梯度流；完整 Newton 方程涉及加速度，通常还需速度、质量及阻尼设定。为保留原文的物理类比，此处明确区分。

可以把采样想象成探索广阔崎岖的景观，许多遥远谷地各对应一个数据模式。Langevin 动力学依赖局部随机更新，难以高效穿越谷地，因而常常无法捕捉分布的全部多样性。这提示我们，需要比纯随机探索更有结构、更有引导的方法，以更有效地在复杂数据流形中行进。

3.2 从基于能量到基于得分的生成模型

EBM 表明，生成只依赖指向更高概率区域的得分，而不依赖完整归一化密度。虽然得分匹配绕开了配分函数，通过能量训练仍需昂贵的二阶导数。关键思想是，既然 Langevin 采样只需要得分，就可直接用神经网络学习它。从能量建模转向得分建模，构成基于得分的生成模型的基础。

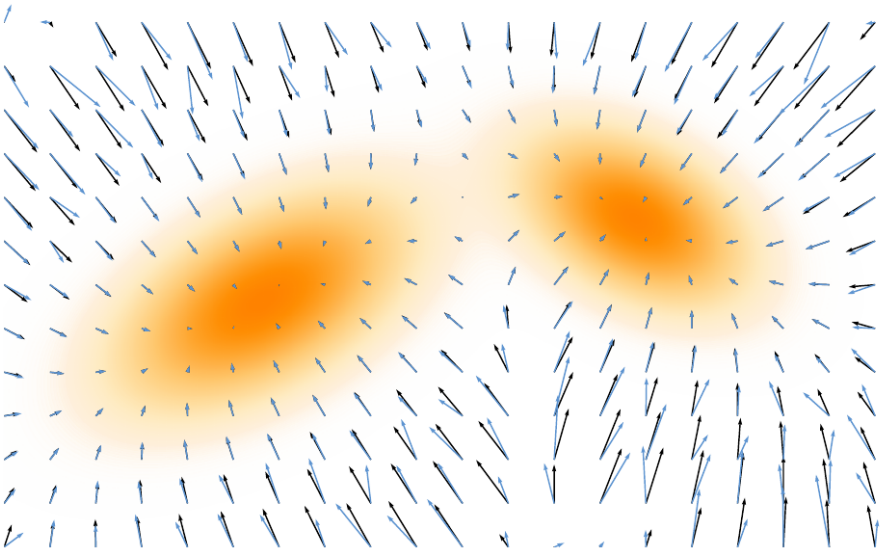


图 3.4: 得分匹配示意。神经网络得分 $s_\phi(x)$ 用均方误差损失训练，以匹配真实得分 $s(x)$；二者均表示为向量场。来源：作者绘制。

3.2.1 用得分匹配训练

得分匹配。 为根据 p_{data} 样本近似得分 $s(x) = \nabla_x \log p_{\text{data}}(x)$，直接用神经网络参数化向量场 $s_\phi(x)$（见图 3.4）：

$$s_\phi(x) \approx s(x).$$

得分匹配通过最小化真实得分与估计之间的均方误差（MSE）拟合这一向量场：

$$\mathcal{L}_{\text{SM}}(\phi) := \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}}[\|s_\phi(x) - s(x)\|_2^2]. \tag{3.2.1}$$

可计算的得分匹配。 初看这一目标不可行，因为作为回归目标的真实得分未知。幸运的是，Hyvärinen and Dayan (2005) 证明，分部积分给出只依赖模型与数据样本的等价目标，无需访问真实得分。关键结果如下。

命题 3.2.1 (Hyvärinen 的可计算得分匹配形式)**.** 可以写成 $\mathcal{L}_{\mathrm{SM}}(\phi) = \widetilde{\mathcal{L}}_{\mathrm{SM}}(\phi) + C$，其中

$$\widetilde{\mathcal{L}}_{\mathrm{SM}}(\phi) := \mathbb{E}_{x\sim p_{\mathrm{data}}(x)}\left[\mathrm{Tr}(\nabla_x s_\phi(x)) + \frac{1}{2}\|s_\phi(x)\|_2^2\right], \tag{3.2.2}$$

C 与 ϕ 无关。最小化解为 $s^*(\cdot) = \nabla_x \log p(\cdot)$。

证明. 展开 $\mathcal{L}_{\mathrm{SM}}$ 中的 MSE，再应用分部积分即可。证明见附录 D.2.1 节。 □

用式 (3.2.2) 的等价目标，仅凭观测数据样本即可训练得分模型，无需真实得分函数。[7]

式 (3.2.2) 的直觉。 可从两项理解替代目标。范数项 $\frac{1}{2}\|s_\phi(x)\|^2$ 惩罚大得分值，尤其在 p_{data} 较大的区域。散度项 $\mathrm{Tr}(\nabla_x s_\phi(x))$ 以正号进入损失，因此最小化目标也偏好局部收缩行为。两项共同给出总体最优得分场 $s^*(x) = \nabla_x \log p_{\mathrm{data}}(x)$。下面进一步解释几何直觉。

幅值项的作用。 期望按数据分布计算，高密度区域对损失贡献更强，因此幅值项在这些区域更强地惩罚大得分值。但单凭这一项，并不意味着每个高密度点都有 $s_\phi(x) = 0$；总体最优时，

$$s^*(x) = \nabla_x \log p_{\mathrm{data}}(x),$$

只在对数密度的驻点为零。

当场（近似）为梯度场时的凹性。 由于散度项以正号进入损失，最小化目标在数据分布强调的区域偏好负散度。负散度表示局部净收缩，但自身不能保证驻点是汇点。为精确说明，假设对标量函数 $u : \mathbb{R}^D \to \mathbb{R}$ 有 $s_\phi = \nabla_x u$，这在匹配对数密度时很自然。于是 $\nabla_x s_\phi = \nabla_x^2 u$ 是 Hessian，$\nabla \cdot s_\phi(x) = \mathrm{Tr}(\nabla_x^2 u(x))$ 是散度。

在驻点 $x_\star$，$s_\phi(x_\star) = \nabla_x u(x_\star) = 0$，二阶 Taylor 展开为

$$u(x) = u(x_\star) + \tfrac{1}{2}(x - x_\star)^\top \nabla_x^2 u(x_\star)(x - x_\star) + o(\|x - x_\star\|^2).$$

若 Hessian $\nabla_x^2 u(x_\star)$ 负定，则 u 在 $x_\star$ 局部凹，对数密度在那里达到严格局部极大值。[8]所有 Hessian 特征值为负，故其迹也为负。此时驻点在得分场下局部吸引，小扰动会被拉回 $x_\star$。

3.2.2 用 Langevin 动力学采样

通过最小化式 (3.2.2) 训练后，模型 $s_{\phi^\times}(x)$ 可在 Langevin 动力学中代替真实得分来采样：

$$x_{n+1} = x_n + \eta s_{\phi^\times}(x_n) + \sqrt{2\eta}\epsilon_n, \qquad \epsilon_n \sim \mathcal{N}(0, I), \tag{3.2.3}$$

$n = 0, 1, 2, \ldots$，初始化为 x_0。与 EBM 式 (3.1.6) 相同，这恰好是连续时间 Langevin SDE 的 Euler–Maruyama 离散化：

$$dx(t) = s_{\phi^\times}(x(t))\, dt + \sqrt{2}\, dw(t),$$

初值为 $x(0)$。因此小步长极限下，离散与连续表述一致。实践中可以运行离散采样器，也可以直接模拟 SDE。

[7]译注：此处需满足分部积分的边界消失和可积性条件；最小化解的等式也取决于模型类是否能够表示真实得分。原命题在本节未展开这些假设。

[8]严格凹性（因而对数密度的严格局部极大值）需要整个 Hessian 负定，而非仅仅迹为负。负迹只保证特征值之和为负，其中仍可能有正特征值，导致鞍点而不是极大点。译注：这里按原文保留该充分条件的解释；负定 Hessian 是非退化二阶判据，并非严格局部极大值的一般必要条件。

3.2.3 序曲：基于得分的生成模型

本章剩余部分将研究得分函数在现代扩散模型中的基础作用。它最初用于高效训练 EBM，如今已成为新一代生成模型的核心组成。我们将在此基础上探索，得分如何影响基于得分的扩散模型的理论表述和实际实现，为通过随机过程生成数据提供有原则的框架。

3.3 去噪得分匹配

3.3.1 动机

虽然式 (3.2.2) 的替代目标

$$\widetilde{\mathcal{L}}_{\mathrm{SM}}(\phi) = \mathbb{E}_{x\sim p_{\mathrm{data}}}[\mathrm{Tr}(\nabla_x s_\phi(x)) + \tfrac{1}{2}\|s_\phi(x)\|_2^2]$$

更易计算，但仍要求 Jacobian 的迹。虽然无需构造完整 Jacobian，精确计算一般仍需汇集输入各坐标的导数信息，代价随 D 增加，在高维中可能昂贵。

切片得分匹配（Song et al., 2020b）以基于随机投影的随机估计替代迹项。下面简述其思想。

切片得分匹配与 Hutchinson 估计量。 对随机 “切片” 方向的导数取平均，替代得分匹配中的迹。令 $u \in \mathbb{R}^D$ 为各向同性随机向量，例如 Rademacher 或标准高斯，满足 $\mathbb{E}[u] = 0$、$\mathbb{E}[uu^\top] = I$。由 Hutchinson 恒等式

$$\mathrm{Tr}(A) = \mathbb{E}_u[u^\top A u], \qquad \mathbb{E}_u[(u^\top s_\phi(x))^2] = \|s_\phi(x)\|_2^2,$$

得到精确形式

$$\widetilde{\mathcal{L}}_{\mathrm{SM}}(\phi) = \mathbb{E}_{x,u}[u^\top(\nabla_x s_\phi(x))u + \tfrac{1}{2}(u^\top s_\phi(x))^2].$$

该目标可用自动微分高效计算：使用 Jacobian—向量积 / 向量—Jacobian 积（JVP / VJP），无需显式计算大型 Jacobian 或 Hessian。对 K 个随机探针平均，得到方差为 $O(1/K)$ 的无偏估计量；方向项 $u^\top(\nabla_x s_\phi)u$ 可用 JVP / VJP 高效计算。直观地，我们只沿随机方向检查模型行为，使投影得分朝高数据密度区域对齐，从而数据点在期望意义下成为驻点。[9]

从切片到去噪得分匹配。 切片方法避免显式 Jacobian，却仍依赖原始数据分布，因而较脆弱：图像数据若位于低维流形上，$\nabla_x \log p_{\mathrm{data}}(x)$ 可能未定义或不稳定；方法只在观测点约束向量场，邻域控制较弱，还存在探针方差和反复 JVP / VJP 的代价。下面重点讨论更稳健的去噪得分匹配（DSM）（Vincent, 2011），它提供有原则、可扩展的解决方案。

3.3.2 训练

重新考察式 (3.2.1)：

$$\mathcal{L}_{\mathrm{SM}}(\phi) = \frac{1}{2}\mathbb{E}_{x\sim p_{\mathrm{data}}(x)}[\|s_\phi(x) - \nabla_x \log p_{\mathrm{data}}(x)\|_2^2],$$

困难来自无法计算的数据得分。

[9]译注：保留原文直觉；精确最优得分在一般数据点不为零，只有对数密度驻点才为零，不能将最后一句理解为每个观测点都是得分场驻点。

Vincent（2011）的条件化解法。 通过已知条件分布 $p_\sigma(\widetilde{x} \mid x)$，以尺度 σ 向 $x \sim p_{\text{data}}$ 注入噪声。网络 $s_\phi(\widetilde{x}, \sigma)$ 通过最小化

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) := \tfrac{1}{2}\mathbb{E}_{\widetilde{x} \sim p_\sigma}[\|s_\phi(\widetilde{x}, \sigma) - \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x})\|_2^2] \tag{3.3.1}$$

来近似扰动边缘分布 $p_\sigma(\widetilde{x}) = \int p_\sigma(\widetilde{x} \mid x) p_{\text{data}}(x)\, dx$ 的得分。虽然边缘得分一般难计算，Vincent (2011) 说明，以 $x \sim p_{\text{data}}$ 为条件可得到等价、可计算的 DSM 损失：

$$\mathcal{L}_{\text{DSM}}(\phi; \sigma) := \tfrac{1}{2}\mathbb{E}_{x \sim p_{\text{data}}, \widetilde{x} \sim p_\sigma(\cdot \mid x)}[\|s_\phi(\widetilde{x}, \sigma) - \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x} \mid x)\|_2^2]. \tag{3.3.2}$$

最优解满足 $s^*(\widetilde{x}, \sigma) = \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x})$，也是式 (3.3.1) 的最优解。例如方差为 σ^2 的高斯扰动

$$p_\sigma(\widetilde{x} \mid x) = \mathcal{N}(\widetilde{x}; x, \sigma^2 I)$$

具有闭式条件得分（见式 (3.3.4)），使回归目标显式可计算。此外，$\sigma \approx 0$ 时，$p_\sigma(\widetilde{x}) \approx p_{\text{data}}(x)$，且

$$s^*(\widetilde{x}, \sigma) = \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}) \approx \nabla_x \log p_{\text{data}}(x),$$

表明学得得分近似原数据得分，可用于生成。[10] 下面正式说明两损失在梯度层面的等价性。

定理 3.3.1 ($\mathcal{L}_{\text{SM}}$ 与 $\mathcal{L}_{\text{DSM}}$ 的等价性)**.** *任意固定 $\sigma > 0$，有*

$$\mathcal{L}_{\text{SM}}(\phi; \sigma) = \mathcal{L}_{\text{DSM}}(\phi; \sigma) + C, \tag{3.3.3}$$

C 与参数 ϕ 无关。二者最小化解对几乎处处 $\widetilde{x}$ 满足

$$s^*(\widetilde{x}, \sigma) = \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}).$$

证明. 直接展开两损失的 MSE，所有依赖 ϕ 的项相消，只剩一个与 ϕ 无关的常数差。最小化解与后文命题 4.3.1 的论证相同，详细推导见附录 D.2.2 节。 □

这个定理与 DDPM 定理 2.2.1 一样，说明一个共同关键原理：

洞见 3.3.1 (条件化技巧)**.** *DDPM 的变分视角中也有这一技巧：给定数据点 x，难计算的损失变成可用 Monte Carlo 估计的可计算损失。流视角中也出现相似思想，例如流匹配（Lipman et al., 2022），见后文第 5.2 节。*

特例：加性高斯噪声。 向每个 $x \sim p_{\text{data}}$ 加入方差 σ^2 的高斯噪声：

$$\widetilde{x} = x + \sigma\epsilon, \qquad \epsilon \sim \mathcal{N}(0, I), \qquad p_\sigma(\widetilde{x} \mid x) = \mathcal{N}(\widetilde{x}; x, \sigma^2 I).$$

条件得分的解析形式为 $\nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x} \mid x) = (x - \widetilde{x})/\sigma^2$，因此

$$\begin{aligned} \mathcal{L}_{\text{DSM}}(\phi; \sigma) &= \tfrac{1}{2}\mathbb{E}_{x, \widetilde{x} \mid x}\left[\left\| s_\phi(\widetilde{x}, \sigma) - \frac{x - \widetilde{x}}{\sigma^2} \right\|_2^2\right] \\ &= \tfrac{1}{2}\mathbb{E}_{x, \epsilon}\left[\left\| s_\phi(x + \sigma\epsilon, \sigma) + \frac{\epsilon}{\sigma} \right\|_2^2\right], \end{aligned} \tag{3.3.4}$$

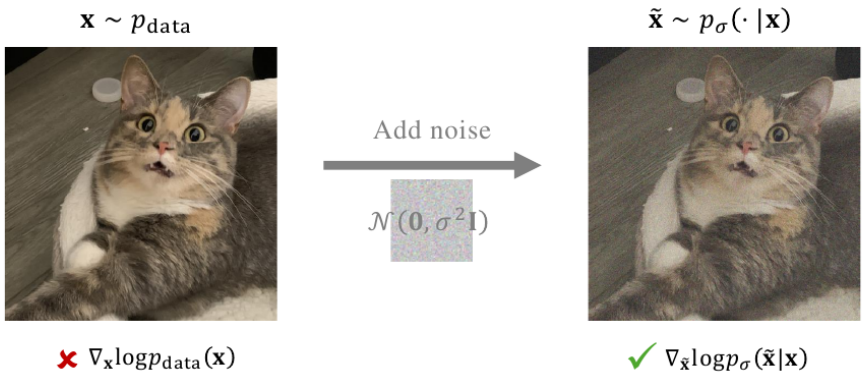


图 3.5: 借助条件化技巧的 DSM 示意。用小加性高斯噪声 $\mathcal{N}(0, \sigma^2 I)$ 扰动数据分布，得到的条件分布 $p_\sigma(\widetilde{x} \mid x) = \mathcal{N}(\widetilde{x}; x, \sigma^2 I)$ 有闭式得分。Add noise 为 “加噪”，叉号 / 勾号表示左侧原数据得分难计算而右侧条件得分可计算。来源：作者绘制。

其中 $\epsilon \sim \mathcal{N}(0, I)$。这一目标构成基于得分的扩散模型的核心。固定 $\sigma > 0$，DSM 学习的是高斯平滑分布 $p_\sigma = p_{\text{data}} * \mathcal{N}(0, \sigma^2 I)$ 的得分，而非原数据分布本身的得分。σ 小时污染较轻，仍紧密保留局部结构，其得分为含噪样本返回可能的数据区域提供有用方向。σ 增大时，高斯平滑逐渐消去细节，合并相近模式，得分主要捕捉粗略、全局结构。这是有用性质：第 3.4 节有意组合多个噪声水平，大噪声用于粗略探索，小噪声用于精细修正。为了更清楚说明 “去噪” 含义，第 3.3.4、3.3.5 节进一步展开。

3.3.3 采样

得到噪声水平 σ 的模型 $s_{\phi^\times}(\widetilde{x}, \sigma)$ 后，以学得模型替代真实得分，运行 Langevin 动力学生成样本：

$$\widetilde{x}_{n+1} = \widetilde{x}_n + \eta \underbrace{s_{\phi^\times}(\widetilde{x}_n, \sigma)}_{\approx \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}_n)} + \sqrt{2\eta}\epsilon_n, \qquad \epsilon_n \sim \mathcal{N}(0, I). \tag{3.3.5}$$

从 $\widetilde{x}_0$ 出发，$n = 0, 1, 2, \ldots$。若 σ 足够小，迭代充分后样本近似来自 p_{data}。

注入噪声的优点。 相较于式 (3.2.1) 的普通得分匹配，注入高斯噪声形成 p_σ 有两个主要优点 (Song and Ermon, 2019)：

- **定义良好的梯度：**噪声将数据扰离低维流形，得到在 $\mathbb{R}^D$ 具有全支集的分布，其得分处处定义良好。

- **改善覆盖：**噪声平滑模式之间的稀疏区域，改善训练信号，使 Langevin 动力学更有效穿越低密度区域。

[10]译注：小噪声密度接近并不自动保证得分接近；若原分布没有环境空间中的光滑正密度，例如位于低维流形，原得分可能不存在。此处保留原文直觉，小噪声得分收敛需额外正则性。

3.3.4 为什么 DSM 是去噪：Tweedie 公式

Tweedie 公式（Efron, 2011）为仅根据含噪观测去噪提供有原则的基础。给定未知 $x \sim p_{\text{data}}$ 的单个高斯污染观测 $\widetilde{x} \sim \mathcal{N}(\cdot; \alpha x, \sigma^2 I)$，沿噪声边缘得分方向，以 σ^2 为步长推动 $\widetilde{x}$，即可得到去噪估计，即给定观测后对所有合理干净信号的平均。噪声边缘定义为

$$p_\sigma(\widetilde{x}) := \int \mathcal{N}(\widetilde{x}; \alpha x, \sigma^2 I) p_{\text{data}}(x)\, dx.$$

引理 3.3.2 (Tweedie 公式)**.** *假设 $x \sim p_{\text{data}}$，给定 x 后 $\widetilde{x} \sim \mathcal{N}(\cdot; \alpha x, \sigma^2 I)$，$\alpha \neq 0$。则*

$$\alpha \mathbb{E}_{x \sim p(x \mid \widetilde{x})}[x \mid \widetilde{x}] = \widetilde{x} + \sigma^2 \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}), \tag{3.3.6}$$

期望对给定 $\widetilde{x}$ 的后验 $p(x \mid \widetilde{x})$ 取。

证明. 计算边缘 $p(\widetilde{x}) = \int p(\widetilde{x} \mid x) p_{\text{data}}(x)\, dx$ 的得分。在积分号内求导，利用条件密度的高斯形式，直接得到可重排成得分与后验均值恒等式的表达。详见附录 D.2.3 节。 □

Tweedie 公式在引入多层噪声的 DDPM 等扩散模型中有核心作用。它使得通过得分从含噪观测估计干净样本，建立得分预测与去噪器的基础联系：

$$\underbrace{\mathbb{E}[x \mid \widetilde{x}]}_{\text{从含噪观测估计的去噪器}} = \frac{1}{\alpha}\big(\widetilde{x} + \sigma^2 \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x})\big).$$

特别地，以 σ^2 为特定步长，对含噪对数似然作一次梯度上升就是去噪估计（条件平均干净信号）。这将 DSM 训练与去噪紧密联系：若 DSM 得到 $s_\phi(\widetilde{x}) \approx \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x})$，则去噪器为 $\alpha^{-1}(\widetilde{x} + \sigma^2 s_\phi(\widetilde{x}))$。[11]

（可选）高阶 Tweedie 公式。 经典公式用对数边缘的梯度表示后验均值。高阶扩展（Meng et al., 2021a）用 $\log p(\widetilde{x})$ 的更高阶导数表示后验协方差和高阶累积量。

带对数归一化子 $\lambda(\widetilde{x})$ 的指数族设定。 假定给定潜在自然参数 $\eta \in \mathbb{R}^D$ 后的条件律属于自然指数族：

$$q_\sigma(\widetilde{x} \mid \eta) = \exp(\eta^\top \widetilde{x} - \psi(\eta)) q_0(\widetilde{x}).$$

q_0 是基测度，即不依赖 η 的部分；对方差 $\sigma^2 I$ 的加性高斯噪声，它为

$$q_0(\widetilde{x}) = (2\pi\sigma^2)^{-D/2} \exp(-\|\widetilde{x}\|^2/(2\sigma^2)).$$

令 $p(\eta)$ 为预定潜在自然参数分布，可视作重参数化的干净数据分布；高斯位置模型中 $\eta = x/\sigma^2$。含噪观测边缘与其对数归一化子为

$$p_\sigma(\widetilde{x}) = \int q_\sigma(\widetilde{x} \mid \eta) p(\eta)\, d\eta, \qquad \lambda(\widetilde{x}) := \log p_\sigma(\widetilde{x}) - \log q_0(\widetilde{x}).$$

给定观测的后验为

$$p(\eta \mid \widetilde{x}) \propto \exp(\eta^\top \widetilde{x} - \psi(\eta) - \lambda(\widetilde{x})) p(\eta),$$

表明将 $\widetilde{x}$ 视为参数时，后验是以 $\widetilde{x}$ 为自然参数、η 为充分统计量、λ 为对数配分函数的指数族。

[11] 译注：$\alpha \neq 1$ 时，单次梯度步给出的是 $\alpha\mathbb{E}[x \mid \widetilde{x}]$，还需除以 α。原文的文字概述应结合公式中的缩放理解。

λ 的导数产生后验累积量。 这里有两条简单规则。第一是归一化，对每个 $\widetilde{x}$，

$$\int \exp(\eta^\top \widetilde{x} - \psi(\eta) - \lambda(\widetilde{x}))p(\eta)\, d\eta = 1.$$

对 $\widetilde{x}$ 求导，从指数中提出 η 的幂以及 λ 的导数，令结果为零，得到导数与后验矩的等式。第二是指数族的标准性质：对数配分函数是充分统计量的累积量生成函数。因此

$$\begin{aligned} \nabla_{\widetilde{x}}\lambda(\widetilde{x}) &= \mathbb{E}[\eta \mid \widetilde{x}], & \nabla^2_{\widetilde{x}}\lambda(\widetilde{x}) &= \mathrm{Cov}[\eta \mid \widetilde{x}], \\ \nabla^{(k)}_{\widetilde{x}}\lambda(\widetilde{x}) &= \kappa_k(\eta \mid \widetilde{x}), & k &\geq 3, \end{aligned}$$

κ_k 是给定观测的 k 阶条件累积量，按标准矩—累积量关系得到。这些就是高阶 Tweedie 公式。对高斯位置模型 $\eta = x/\sigma^2$，化为

$$\begin{aligned} \mathbb{E}[x \mid \widetilde{x}] &= \widetilde{x} + \sigma^2 \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}), \\ \mathrm{Cov}[x \mid \widetilde{x}] &= \sigma^2 I + \sigma^4 \nabla^2_{\widetilde{x}} \log p_\sigma(\widetilde{x}), \end{aligned}$$

更高阶累积量由更高阶对数密度导数按相应尺度给出。已有研究训练神经网络估计高阶得分（Meng et al., 2021a; Lu et al., 2022a; Lai et al., 2023a）；这里侧重澄清其与统计量的关系，方法细节请参阅这些工作。

3.3.5 （可选）为什么 DSM 是去噪：SURE

Stein 无偏风险估计量。 SURE 能在不知道干净信号时估计去噪器 $\mathbf{D}$ 的均方误差，因此仅有含噪数据时也能选择或训练去噪器。考虑加性高斯噪声 $\widetilde{x} = x + \sigma\epsilon$，$\epsilon \sim \mathcal{N}(0, I)$；$x \in \mathbb{R}^D$ 为未知干净信号，$\widetilde{x}$ 为观测。去噪器是任意弱可微映射 $\mathbf{D} : \mathbb{R}^D \to \mathbb{R}^D$，输出估计 $\mathbf{D}(\widetilde{x})$。

自然质量指标是条件均方误差

$$R(\mathbf{D}; x) := \mathbb{E}_{\widetilde{x}|x}[\|\mathbf{D}(\widetilde{x}) - x\|_2^2 \mid x].$$

它依赖未知真实 x，无法直接计算。Stein 恒等式（附录 D.2.4 节）给出可观测替代量

$$\mathrm{SURE}(\mathbf{D}; \widetilde{x}) = \|\mathbf{D}(\widetilde{x}) - \widetilde{x}\|_2^2 + 2\sigma^2 \nabla_{\widetilde{x}} \cdot \mathbf{D}(\widetilde{x}) - D\sigma^2, \tag{3.3.7}$$

其中 $\nabla_{\widetilde{x}} \cdot \mathbf{D}(\widetilde{x})$ 为去噪器散度。它只需要含噪观测，不需要干净 x。[12]

直观地，SURE 的两部分相互补充。$\|\mathbf{D}(\widetilde{x}) - \widetilde{x}\|^2$ 衡量输出距含噪输入多远；单用它会低估真实误差，因为输入已受污染。散度项作修正，捕捉去噪器对输入小扰动的敏感度，从而计入噪声引入的方差。

对任意固定但未知的 x，

$$\mathbb{E}_{\widetilde{x}|x}[\mathrm{SURE}(\mathbf{D}; x + \sigma\epsilon) \mid x] = R(\mathbf{D}; x),$$

期望对高斯噪声取。因此在期望意义或经验上最小化 SURE，相当于仅依靠含噪数据最小化真实均方误差。实际中，对 $x \sim p_{\mathrm{data}}$ 和污染噪声共同平均，得到全局均方误差风险的无偏估计。[13]

[12]译注：原文以粗体 $\mathbf{D}$ 表示去噪器、斜体 D 表示环境维数；此处保留这一字体区别，式中末项 $D\sigma^2$ 使用维数。

[13]译注：无偏等式针对满足 Stein 正则条件的固定去噪器及期望；有限样本经验最优与总体最优并不严格相同，若从同一数据中自适应选择去噪器，还需区分选择带来的统计效应。

与 Tweedie 公式及 Bayes 最优性的联系。 令 $p_\sigma(\widetilde{x}) = (p_{\text{data}} * \mathcal{N}(0, \sigma^2 I))(\widetilde{x})$。SURE 对给定 x 的噪声均方误差无偏：

$$\mathbb{E}_{\widetilde{x}|x}[\text{SURE}(\mathbf{D}; \widetilde{x})] = \mathbb{E}_{\widetilde{x}|x}[\|\mathbf{D}(\widetilde{x}) - x\|^2].$$

由全期望法则，最小化期望 SURE 等于最小化 Bayes 风险

$$\mathbb{E}_{(x,\widetilde{x})}[\|\mathbf{D}(\widetilde{x}) - x\|^2] = \mathbb{E}_{\widetilde{x}}[\mathbb{E}_{x|\widetilde{x}}[\|\mathbf{D}(\widetilde{x}) - x\|^2]].$$

这给出逐点优化：对几乎处处 $\widetilde{x}$，

$$\mathbf{D}^*(\widetilde{x}) = \arg\min_z \mathbb{E}_{x|\widetilde{x}}[\|z - x\|^2] = \mathbb{E}[x \mid \widetilde{x}].$$

因此 SURE 最优去噪器与第 3.3.4 节的 Bayes 估计相同，由 Tweedie 恒等式，

$$\mathbf{D}^*(\widetilde{x}) = \mathbb{E}[x \mid \widetilde{x}] = \widetilde{x} + \sigma^2 \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}). \tag{3.3.8}$$

SURE 与得分匹配的关系。 式 (3.3.8) 启发用得分场参数化去噪器：

$$\mathbf{D}(\widetilde{x}) = \widetilde{x} + \sigma^2 s_\phi(\widetilde{x}, \sigma),$$

$s_\phi(\cdot, \sigma)$ 用于近似含噪得分。代入式 (3.3.7) 得

$$\frac{1}{2\sigma^4}\,\text{SURE}(\mathbf{D}; \widetilde{x}) = \text{Tr}(\nabla_{\widetilde{x}} s_\phi(\widetilde{x}, \sigma)) + \tfrac{1}{2}\|s_\phi(\widetilde{x}, \sigma)\|_2^2 + \text{const}(\sigma).$$

因此对 $\widetilde{x} \sim p_\sigma$ 取期望，最小化 SURE 等价于最小化噪声水平 σ 的 Hyvärinen 替代得分匹配目标，仅差加法常数，期望在 p_σ 下取（式 (3.2.2)）。二者具有相同最小化解，即式 (3.3.8)。

3.3.6 （可选）广义得分匹配

动机。 经典得分匹配、DSM 和高阶变体都以某个密度 p 上的 $Lp(x)/p(x)$ 为目标，其中线性算子 L 作用于密度。经典情形 $L = \nabla_x$，得到 $\nabla_x \log p(x) = \nabla_x p(x)/p(x)$。这一结构使分部积分能够消去归一化常数，得到只依赖 p 的样本和学得场的可计算目标，启发广义得分匹配框架。

广义 Fisher 散度。 令 p 为数据分布，q 为任意模型分布。对作用于 x 的标量函数的线性算子 L，定义

$$D_L(p\|q) := \int p(x) \left\| \frac{Lp(x)}{p(x)} - \frac{Lq(x)}{q(x)} \right\|_2^2 dx.$$

如果 L 是完备的，即 $Lp_1/p_1 = Lp_2/p_2$ 几乎处处蕴含 $p_1 = p_2$ 几乎处处，那么 $D_L(p\|q) = 0$ 识别出 $q = p$。取 $L = \nabla_{\widetilde{x}}$ 恢复经典 Fisher 散度（式 (1.1.3)）。

得分参数化。 实际中不建模归一化密度 q，而直接参数化向量场 $s_\phi(x)$ 来近似广义得分。考虑

$$D_L(p\|s_\phi) := \mathbb{E}_{x\sim p}\left[\left\|s_\phi(x) - \frac{Lp(x)}{p(x)}\right\|_2^2\right].$$

虽然目标未知，“分部积分”可使损失只依赖 s_ϕ。设 $L^\dagger$ 为伴随算子，对任意测试函数 f, g，

$$\int (Lf)^\top g = \int f(L^\dagger g).$$

边界项消失时，这形式上将 L 移过积分。展开平方并应用该恒等式，得到

$$\mathcal{L}_{\mathrm{GSM}}(\phi) = \mathbb{E}_{x\sim p}[\tfrac{1}{2}\|s_\phi(x)\|_2^2 - (L^\dagger s_\phi)(x)] + \mathrm{const},$$

常数与 ϕ 无关。只通过期望使用 p，因而与经典得分匹配一样，可从训练数据经验估计。$L = \nabla$ 时 $L^\dagger = -\nabla\cdot$，恢复式 (3.2.2)。

算子的例子。

- **经典得分匹配：** 取 $L = \nabla_x$，广义得分为 $Lp(x)/p(x) = \nabla_x \log p(x)$。
- **去噪得分匹配：** 加性高斯噪声下，定义

$$\begin{aligned}(Lf)(\widetilde{x}) &= \widetilde{x} f(\widetilde{x}) + \sigma^2 \nabla_{\widetilde{x}} f(\widetilde{x}),\\ \frac{Lp_\sigma(\widetilde{x})}{p_\sigma(\widetilde{x})} &= \widetilde{x} + \sigma^2 \nabla_{\widetilde{x}} \log p_\sigma(\widetilde{x}) = \mathbb{E}[x_0 \mid \widetilde{x}],\\ p_\sigma(\widetilde{x}) &:= \int \mathcal{N}(\widetilde{x}; x_0, \sigma^2 I) p_{\mathrm{data}}(x_0)\, dx_0, \qquad \widetilde{x} = x_0 + \sigma\epsilon.\end{aligned}$$

  这恰好是加性高斯噪声的 Tweedie 恒等式。最小化相应广义目标，训练 s_ϕ 近似后验均值去噪器。缩放高斯位置模型 $\widetilde{x} = \alpha x_0 + \sigma\epsilon$ 则包含式 (3.3.6) 的因子 α。

- **高阶目标：** 在 L 中堆叠导数会揭示 $\nabla^2 \log p$ 及更高阶导数，与后验协方差和高阶累积量对应。[14]

扩展与用途。 广义得分匹配从连续变量扩展到离散设定，包括语言建模（Meng et al., 2022; Lou et al., 2024），也启发产生去噪型目标的得分式训练。算子视角统一多类目标，支持从数据经验估计，并通过恰当选择 L，提供设计损失函数的一般原则。

3.4 多噪声水平的去噪得分匹配（NCSN）

3.4.1 动机

单个固定方差高斯噪声能将数据分布平滑到一定程度，但只在一个噪声水平训练有关键局限。噪声低时，Langevin 动力学因低密度区域梯度消失而难以穿越多峰分布的模式；噪声高时，采样较容易，却只能捕捉粗略结构，样本模糊、缺乏细节。此外，高维空间中它可能收敛缓慢甚至失效。它依赖对数密度梯度指引，差的初始化，特别在平台区或鞍点附近，可能阻碍探索，或

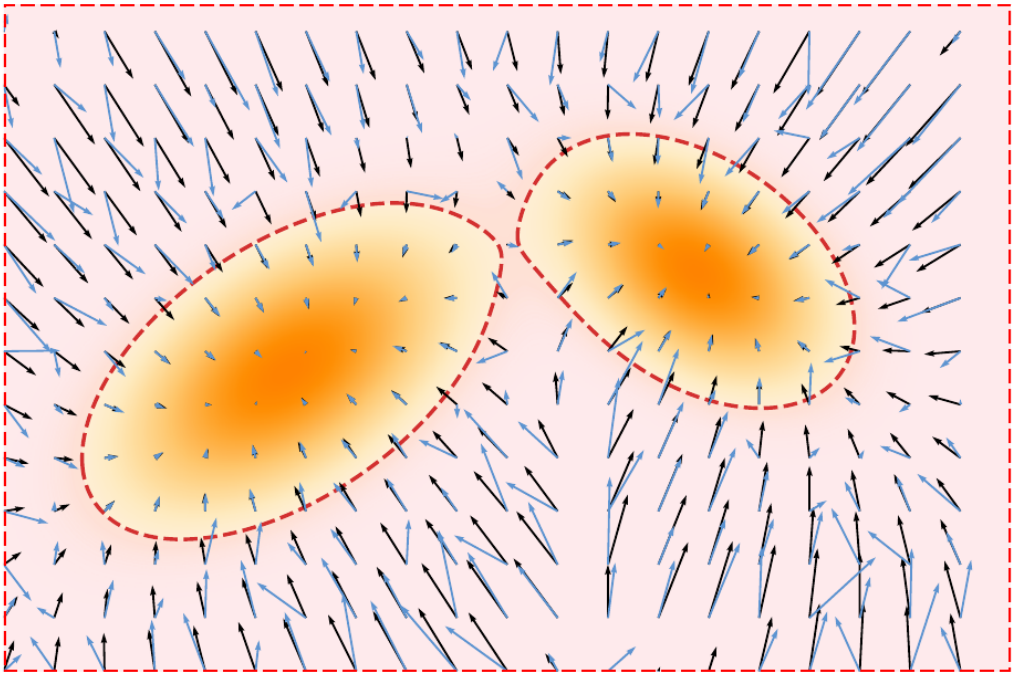


图 3.6: 得分匹配不准确性的示意（重访图 3.4）。红色区域表示低密度区域，样本覆盖有限时得分估计可能不准确；高密度区域的估计通常更准确。来源：作者绘制。

使采样器困在单一模式。为处理这些挑战，Song and Ermon (2019) 提议向数据分布注入多个水平的高斯噪声，联合训练噪声条件得分网络（NCSN），估计一系列尺度的得分。生成时按噪声退火方式运行 Langevin 动力学：从高噪声开始粗略探索，逐渐走向低噪声，恢复细节。

3.4.2 训练

为克服单噪声水平模型局限，选择 L 个噪声水平，

$$0 < \sigma_1 < \sigma_2 < \cdots < \sigma_L,$$

σ_1 小到足以保留大部分精细结构，σ_L 大到足以充分平滑分布，便于训练。每个含噪样本由 $x \sim p_{\text{data}}$ 经 $x_\sigma = x + \sigma\epsilon$、$\epsilon \sim \mathcal{N}(0, I)$ 构造，定义扰动核与边缘分布

$$p_\sigma(x_\sigma \mid x) := \mathcal{N}(x_\sigma; x, \sigma^2 I),$$
$$p_\sigma(x_\sigma) = \int p_\sigma(x_\sigma \mid x) p_{\text{data}}(x)\, dx.$$

每个噪声水平都对应高斯平滑的数据分布。

NCSN 训练目标。 目标是训练 $s_\phi(x, \sigma)$，估计所有 $\sigma \in \{\sigma_i\}_{i=1}^L$ 的得分 $\nabla_x \log p_\sigma(x)$。为此在所有噪声水平最小化 DSM：

$$\mathcal{L}_{\text{NCSN}}(\phi) := \sum_{i=1}^{L} \lambda(\sigma_i) \mathcal{L}_{\text{DSM}}(\phi; \sigma_i), \tag{3.4.1}$$

[14]译注：单纯取 $L = \nabla^2$ 得到 $\nabla^2 p/p = \nabla^2 \log p + (\nabla \log p)(\nabla \log p)^\top$，不直接等于对数密度 Hessian；需结合低阶得分项恢复对数导数。原文此处为概述，保留并明确区别。

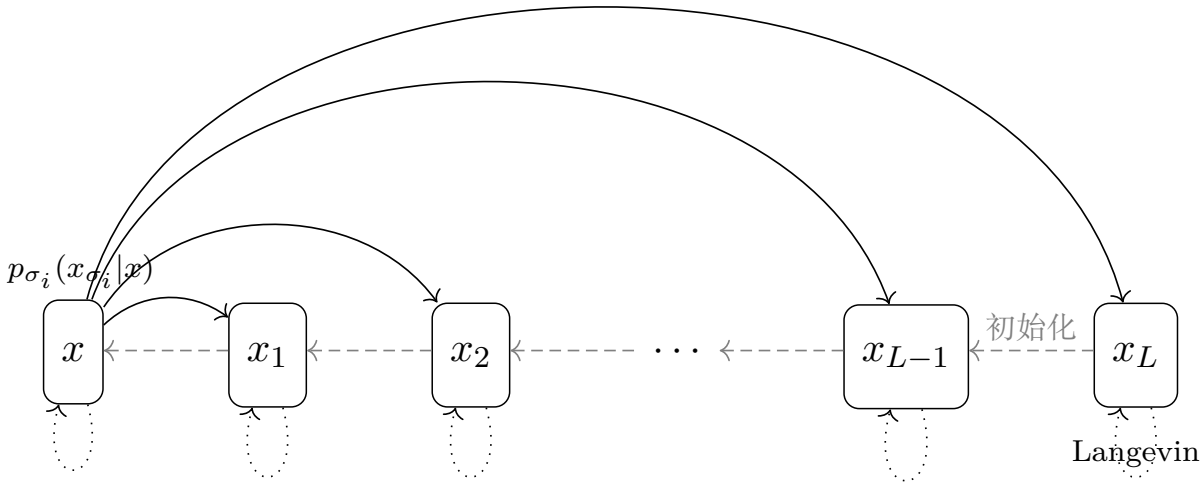


图 3.7: NCSN 示意。正向过程以多个加性高斯噪声水平 $p_\sigma(x_\sigma \mid x)$ 扰动数据。生成（虚线）在各噪声水平上运行 Langevin 采样，用当前水平的结果初始化下一较低方差水平。Initialize 为 “初始化”。来源：作者绘制。

其中

$$\mathcal{L}_{\mathrm{DSM}}(\phi;\sigma) = \tfrac{1}{2}\mathbb{E}_{x\sim p_{\mathrm{data}}(x),\widetilde{x}\sim p_\sigma(\widetilde{x}|x)}\left[\left\| s_\phi(\widetilde{x},\sigma) - \frac{x-\widetilde{x}}{\sigma^2}\right\|_2^2\right],$$

$\lambda(\sigma_i) > 0$ 为各尺度权重。它本质上是 DSM 最小化（定理 3.3.1），得到在每个噪声水平恢复真实得分的模型：

$$s^*(\cdot,\sigma) = \nabla_x \log p_\sigma(\cdot), \qquad\qquad \forall\sigma \in \{\sigma_i\}_{i=1}^L.$$

与 DDPM 损失的关系。 令 $x_\sigma = x + \sigma\epsilon$，$\epsilon \sim \mathcal{N}(0,I)$，$p_\sigma$ 为边缘。由 Tweedie 公式，

$$\nabla_{x_\sigma} \log p_\sigma(x_\sigma) = -\frac{1}{\sigma}\mathbb{E}[\epsilon \mid x_\sigma].$$

因此 NCSN 最优解是真实得分，而 DDPM 损失式 (2.2.10) 的 Bayes 最优噪声预测为 $\epsilon^*(x_\sigma,\sigma) = \mathbb{E}[\epsilon \mid x_\sigma]$。二者精确等价：

$$s^*(x_\sigma,\sigma) = -\sigma^{-1}\epsilon^*(x_\sigma,\sigma), \qquad\qquad \epsilon^*(x_\sigma,\sigma) = -\sigma s^*(x_\sigma,\sigma).$$

DDPM 中第 i 步含噪样本可写为

$$\sigma_i := \sqrt{1-\bar{\alpha}_i^2}, \qquad\qquad x_i = \bar{\alpha}_i x_0 + \sigma_i\epsilon, \qquad\qquad \epsilon\sim\mathcal{N}(0,I),$$

所以得分与最优噪声预测包含同一信息：$s^*(x_i,i) = -\sigma_i^{-1}\mathbb{E}[\epsilon \mid x_i]$。换言之，在已知尺度因子 $1/\sigma_i$ 下，DDPM 预测噪声等价于预测第 i 噪声水平得分。第 6 章将系统比较总结这些参数化等价性。

3.4.3 采样

有了多个噪声水平的训练模型 $s_{\phi^\times}(\cdot,\sigma_1),\dots,s_{\phi^\times}(\cdot,\sigma_L)$，退火 Langevin 动力学（Song and Ermon, 2019）从高噪声 σ_L 逐渐去噪到低噪声 $\sigma_1\approx 0$，生成数据。

从简单初始化 $x\sim p_{\text{init}}$ 开始，先在最大噪声水平运行 Langevin 动力学，得分引导样本走向平滑分布 p_{σ_L}。再用结果初始化下一较低噪声水平，反复操作，直到最小水平。在各 σ_ℓ，更新为

$$\widetilde{x}_{n+1}=\widetilde{x}_n+\eta_\ell s_{\phi^\times}(\widetilde{x}_n,\sigma_\ell)+\sqrt{2\eta_\ell}\epsilon_n,\qquad\qquad \epsilon_n\sim\mathcal{N}(0,I),$$

前一水平的输出提供初值 $\widetilde{x}_0$。常用步长按噪声缩放：

$$\eta_\ell=\delta\frac{\sigma_\ell^2}{\sigma_1^2},\qquad\qquad \delta>0.$$

算法在所有噪声水平，包括 σ_1，执行 Langevin 更新，所以最终样本在最小噪声水平修正后才得到。算法 1 总结过程。初始化分布只给 Markov 链一个起点。在最大噪声水平，Langevin 动力学将其推向 p_{σ_L}，随后逐个噪声水平引导样本走向平滑越来越少的数据分布。

算法 1 退火 Langevin 动力学

输入： 训练好的得分 $s_{\phi^\times}(\cdot,\sigma_\ell)$，各水平 $\ell=L,\dots,1$ 的步长 η_ℓ 和迭代预算 N_ℓ，初始化分布 p_{init}。

$x\sim p_{\text{init}}$ ▷ 从最大噪声水平的无结构噪声初始化
for $\ell=L,L-1,\dots,1$ **do**
  $\widetilde{x}_0\leftarrow x$ ▷ 以前一水平输出初始化
  for $n=0,\dots,N_\ell-1$ **do**
    $\epsilon_n\sim\mathcal{N}(0,I)$
    $\widetilde{x}_{n+1}\leftarrow\widetilde{x}_n+\eta_\ell s_{\phi^\times}(\widetilde{x}_n,\sigma_\ell)+\sqrt{2\eta_\ell}\epsilon_n$
  end for
  $x\leftarrow\widetilde{x}_{N_\ell}$ ▷ 将最终状态传给下一更小噪声水平
end for

输出： x。

NCSN 的缓慢采样。 NCSN 通过跨噪声尺度的退火 MCMC（通常为 Langevin 动力学）生成样本。每个尺度执行 K 次“按得分更新，加小随机扰动”的迭代，每次都需要一次得分网络前向计算。两项因素使 $L\times K$ 必须较大：

1. **局部精度与稳定性：** 学得得分只对小扰动可靠，需要小步长以及每个水平上的多次迭代，避免偏差或不稳定；

2. **高维慢混合：** 局部 MCMC 对高维多峰目标探索低效，需要许多迭代才能到达典型数据区域。

更新严格顺序化，每次依赖前一次且需要昂贵网络求值，总代价为 $O(LK)$ 次顺序网络计算，采样因而缓慢。

表 3.1: NCSN 与 DDPM 的比较

	NCSN	DDPM
$x_{i+1} \mid x_i$	推导为 $x_{i+1} = x_i + \sqrt{\sigma_{i+1}^2 - \sigma_i^2}\epsilon$	定义为 $x_{i+1} = \sqrt{1-\beta_i}\, x_i + \sqrt{\beta_i}\epsilon$
$x_i \mid x$	定义为 $x_i = x + \sigma_i \epsilon$	推导为 $x_i = \bar{\alpha}_i x + \sqrt{1-\bar{\alpha}_i^2}\epsilon$
p_{prior}	$\mathcal{N}(0, \sigma_L^2 I)$	$\mathcal{N}(0, I)$
损失	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(x)} \mathbb{E}_{\epsilon\sim\mathcal{N}(0,I)} \left[\left\| s_\phi(x_i, \sigma_i) + \frac{\epsilon}{\sigma_i} \right\|_2^2 \right]$	$\mathbb{E}_i \mathbb{E}_{p_{\text{data}}(x)} \mathbb{E}_{\epsilon\sim\mathcal{N}(0,I)} [\|\epsilon_\phi(x_i, i) - \epsilon\|_2^2]$
采样	每层运行 Langevin；用输出初始化下一层	沿 $p_{\phi\times}(x_{i-1} \mid x_i)$ 的 Markov 链运行

3.5 总结：NCSN 与 DDPM 的比较

首先比较图 3.7 所示 NCSN 与 DDPM 的图模型，主要相似与差异汇总于表 3.1。**译注：** 原表 DDPM 行使用 $\sqrt{1-\beta_i}$、$\sqrt{\beta_i}$ 的另一常见方差约定，与本书第 2 章的 $\alpha_i = \sqrt{1-\beta_i^2}$ 不同；这里保留原表，不能把两处 β_i 直接视为同一数值。NCSN 的有限噪声边缘实际为数据与高斯的卷积，表中高斯先验是大噪声初始化近似，非一般的精确边缘。

共同瓶颈。 尽管表述不同，NCSN 与 DDPM 都依赖密集时间离散化，采样常需数百甚至数千次迭代，使生成缓慢且计算昂贵。

问题 3.5.1： 如何加速扩散模型采样?

第 9 章将发展更高效采样器；第 10 章把需数百步采样的预训练扩散模型压缩为少步学生生成器；第 11 章则研究遵循扩散启发的原理，直接从头学习快速少步生成器。

3.6 结束语

本章从根植于 EBM 的得分视角，勾勒扩散模型的第二条主要路径。从 EBM 的核心困难——难计算的配分函数——出发，引入完全绕开它的工具 $\nabla_x \log p(x)$。

我们从经典得分匹配走向更可扩展、更稳健的 DSM。噪声扰动使训练目标可计算，再次通过条件化策略形成简单回归目标。Tweedie 公式建立得分估计与去噪的深刻联系：得分提供从含噪观测估计干净信号的精确方向。

随后用 NCSN 将单噪声水平扩展为多级噪声阶梯：一个条件模型在多个尺度学习得分，并用退火 Langevin 动力学生成样本。下一章将通过得分 SDE 框架，从离散阶梯进一步走向连续噪声水平。

这些联系并非巧合，而暗示更深的统一数学结构。离散时间模型的局限促使我们寻求更一般框架。下一章将迈出关键一步：

1. 转入连续时间，说明 DDPM 和 NCSN 都可统一为某个由 SDE 描述的过程的不同离散化；

2. 用得分 SDE 框架正式联系变分与得分视角，把生成重述为求解微分方程。

这一统一视角不仅澄清理论，还会打开新一类先进数值方法的道路，处理缓慢采样这一根本挑战。

第四章　当代扩散模型：得分 SDE 框架

只有一种精确呈现定律的方法，那就是借助微分方程。它们的优点在于根本，而且据我们所知，是精确的。

Richard P. Feynman

迄今我们从变分和得分两个视角研究扩散模型，后者自然产生于 EBM。现在进入连续时间框架，其核心是得分 SDE（Song et al., 2020c），用连续时间视角将 DDPM 与 NCSN 纳入同一框架。

不再只考虑有限噪声水平，而设想在数据与噪声之间插入越来越多中间水平。连续时间极限下，噪声水平随时间平滑变化，基本图景为

$$p_{\text{data}} \xrightarrow{\text{正向 SDE}} p_T \approx p_{\text{prior}}, \qquad\qquad p_{\text{prior}} \xrightarrow{\text{反向动力学}} p_{\text{data}}.$$

正向 SDE 描述数据如何逐渐污染为噪声，扮演 DDPM 噪声调度或 NCSN 噪声水平序列的连续时间角色。指定正向过程后，生成的主要挑战是反方向：如何从简单噪声分布恢复数据分布？关键量是时间依赖得分 $\nabla_x \log p_t(x)$，描述每个 t 的含噪分布局部几何。一旦知道得分，或用神经网络近似它，就确定了将噪声变回数据的反向动力学。

这给出互补的两种描述：随机逆时间 SDE，以及确定性概率流 ODE（PF-ODE）。虽然样本轨迹不同，它们可以遵循相同的边缘分布演化。连续时间视角将生成变成微分方程求解，打开随机过程、微分方程和数值分析工具的大门。将生成动力学写成 SDE 或 ODE 后，可用标准数值方法模拟，也可用高级求解器提高采样效率与精度。因此它既统一数学描述，也为理解和设计本书后续快速采样方法提供实际基础。

学完本章后，你将能够：

- 理解 DDPM 和 NCSN 的离散噪声水平如何导向逐渐将数据变为噪声的连续时间正向 SDE；
- 理解如何用随机逆时间 SDE 或确定性 PF-ODE 描述从噪声返回数据；
- 解释二者为何能有相同边缘分布序列而各自样本轨迹不同，并理解 Fokker–Planck 方程如何描述概率密度连续演化；
- 理解如何用 DSM 学习时间依赖得分，再通过逆时间 SDE 或 PF-ODE 采样；
- 理解 PF-ODE 如何正向运行进行反演，并用连续变量替换公式跟踪密度变化、计算似然；
- 认识 VE 与 VP SDE 是同一连续时间扩散框架的两个重要实例，分别联系 NCSN 与 DDPM。

阅读路线。 不熟悉 SDE 的读者可按需查阅附录 A。初读重点把握正向 SDE、逆时间 SDE 与 PF-ODE 的作用及训练采样过程，待整体图景明确后再回看高斯例子和可选推导。

4.1 得分 SDE 的原理

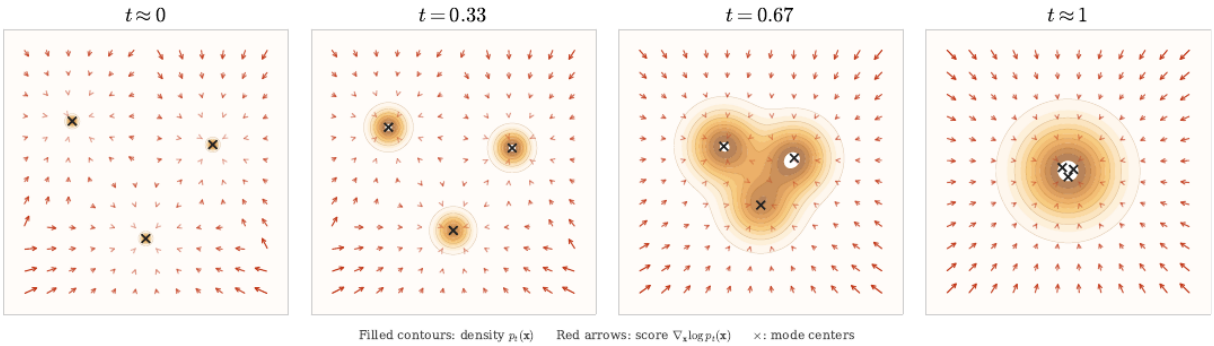


图 4.1: 时间依赖得分景观。噪声增加时，扰动密度 $p_t(x)$ 从集中在数据模式附近的多峰分布，演化为宽广、近似单峰的先验。得分场相应从将样本拉向邻近模式的尖锐局部场，变为指向整体质心的平滑全局场。它是得分 SDE 学习的关键对象。图例为填色等高线：密度；红箭头：得分；叉号：模式中心。来源：作者借助 AI 辅助编程绘制。

多噪声尺度是 NCSN 和 DDPM 成功的关键。本节介绍将噪声水平推广为连续谱的得分 SDE 基础。Sohl-Dickstein et al. (2015) 已注意到正反扩散过程的连续时间极限，Song et al. (2020c) 则将其作为中心，以随机 / 常微分方程描述噪声随时间平滑增加的数据演化。核心是每个水平的得分：它指向当前含噪分布的较高密度区域，恰好确定如何逆转扩散。图 4.1 中，小 t 时得分急剧汇入各数据模式，大 t 时温和指向全局中心。连续时间表述统一先前离散模型，也提供有原则而灵活的生成基础：学得所有噪声水平的得分族后，生成化为微分方程求解。

4.1.1 动机：从离散到连续时间过程

回顾 NCSN 和 DDPM 的正向加噪。NCSN 使用递增的 $\{\sigma_i\}_{i=1}^L$，每个 $x_0 \sim p_{\text{data}}$ 扰动为

$$x_{\sigma_i} = x_0 + \sigma_i \epsilon_i, \qquad \epsilon_i \sim \mathcal{N}(0, I).$$

DDPM 按方差调度 $\{\beta_i\}_{i=1}^L$ 逐步注入噪声：[1]

$$x_i = \sqrt{1-\beta_i}\, x_{i-1} + \sqrt{\beta_i}\epsilon_i, \qquad \epsilon_i \sim \mathcal{N}(0, I).$$

在离散时间网格上统一考察 x_t 到 $x_{t+\Delta t}$ 的更新：[2]

$$\begin{aligned}
\text{NCSN:} \quad & x_{t+\Delta t} = x_t + \sqrt{\sigma_{t+\Delta t}^2 - \sigma_t^2}\,\epsilon_t \approx x_t + \sqrt{\frac{d\sigma_t^2}{dt}\Delta t}\,\epsilon_t, \\
\text{DDPM:} \quad & x_{t+\Delta t} = \sqrt{1-\beta(t)\Delta t}\, x_t + \sqrt{\beta(t)\Delta t}\,\epsilon_t \\
& \qquad \approx x_t - \tfrac{1}{2}\beta(t) x_t \Delta t + \sqrt{\beta(t)\Delta t}\,\epsilon_t,
\end{aligned}$$

[1] 第 2.2 节写成 $x_i = \sqrt{1-\beta_i^2}\, x_{i-1} + \beta_i \epsilon_i$，其中 β_i 为标准差，$\alpha_i = \sqrt{1-\beta_i^2}$。本章遵循 Song et al. (2020c)，改以 β_i 表示方差，$\beta_i^{(\text{本章})} = (\beta_i^{(\text{第 2 章})})^2$，动力学相同。

[2] 为方便，$x(t)$ 与 x_t 交替表示时刻 t 的样本；其他时间依赖变量也类似。

$\epsilon_t \sim \mathcal{N}(0, I)$。二者有共同结构：

$$x_{t+\Delta t} \approx x_t + f(x_t, t)\Delta t + g(t)\sqrt{\Delta t}\epsilon_t, \tag{4.1.1}$$

其中 $f : \mathbb{R}^D \times \mathbb{R} \to \mathbb{R}^D$、$g : \mathbb{R} \to \mathbb{R}$ 为

$$\begin{aligned} &\text{NCSN:} \quad f(x,t) = 0, && g(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}, \\ &\text{DDPM:} \quad f(x,t) = -\tfrac{1}{2}\beta(t)x, && g(t) = \sqrt{\beta(t)}. \end{aligned}$$

相应高斯转移为

$$p(x_{t+\Delta t} \mid x_t) := \mathcal{N}(x_{t+\Delta t}; x_t + f(x_t, t)\Delta t, g^2(t)\Delta t I), \tag{4.1.2}$$

略微滥用记号，把 x_t 视为固定样本、$x_{t+\Delta t}$ 视为随机变量。$\Delta t \to 0$（概念上准备无穷多层噪声）时，离散过程收敛为正向连续时间 SDE：[3]

$$dx(t) = f(x(t), t)\, dt + g(t)\, dw(t),$$

$w(t)$ 是标准 Wiener 过程（Brownian 运动）。

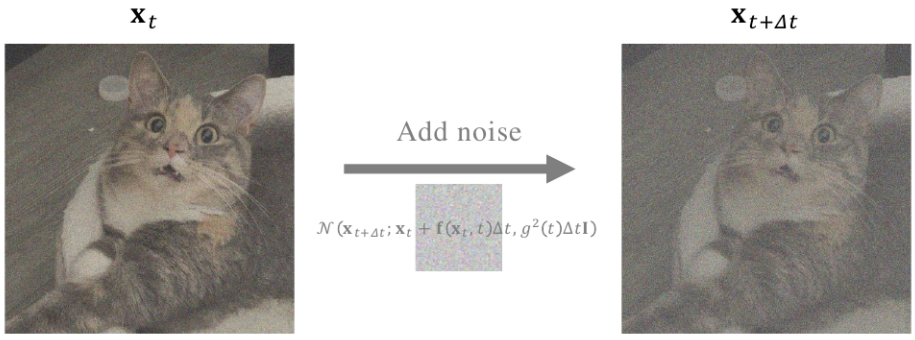


图 4.2: 离散时间加噪步骤。从 t 到 $t+\Delta t$，以均值漂移 $f(x_t, t)$ 和扩散系数 $g(t)$ 加噪。Add noise 表示“加噪”。来源：作者绘制。

注。 这里无需完整形式定义。Wiener 过程从零出发，具有独立增量，任意 $s < t$ 时，$w(t) - w(s)$ 为均值零、方差 $t - s$ 的正态变量。它表示独立高斯涨落随时间累积，几乎必然连续却处处不可微。在无穷小时间区间，增量记为

$$dw(t) := w(t + dt) - w(t), \qquad dw(t) \sim \mathcal{N}(0, dt I).$$

附录 A.2 节简述 SDE 基础，附录 C 有更深入讨论。离散与连续联系可概念性地理解为

- $x(t + \Delta t) - x(t) \approx dx(t)$；
- $\Delta t \approx dt$；
- $\sqrt{\Delta t}\epsilon_t \sim \mathcal{N}(0, \Delta t I) \approx dw(t)$。

指定漂移和扩散后，正向 SDE 自动诱导把终端噪声返回数据分布的逆时间 SDE。反向动力学只有一个未知项，恰好是各连续时间水平的得分。这确定了得分匹配训练目标；学得得分后，采样就是数值积分逆时间 SDE。第 4.3 节给实际实现，先在下面两节研究正反过程理论。

[3]式 (4.1.2) 的核在 $\Delta t \to 0$ 时收敛于相应 Itô SDE 的解。严格证明依赖高级结果，此处留给文献。

4.1.2 正向时间 SDE：从数据到噪声

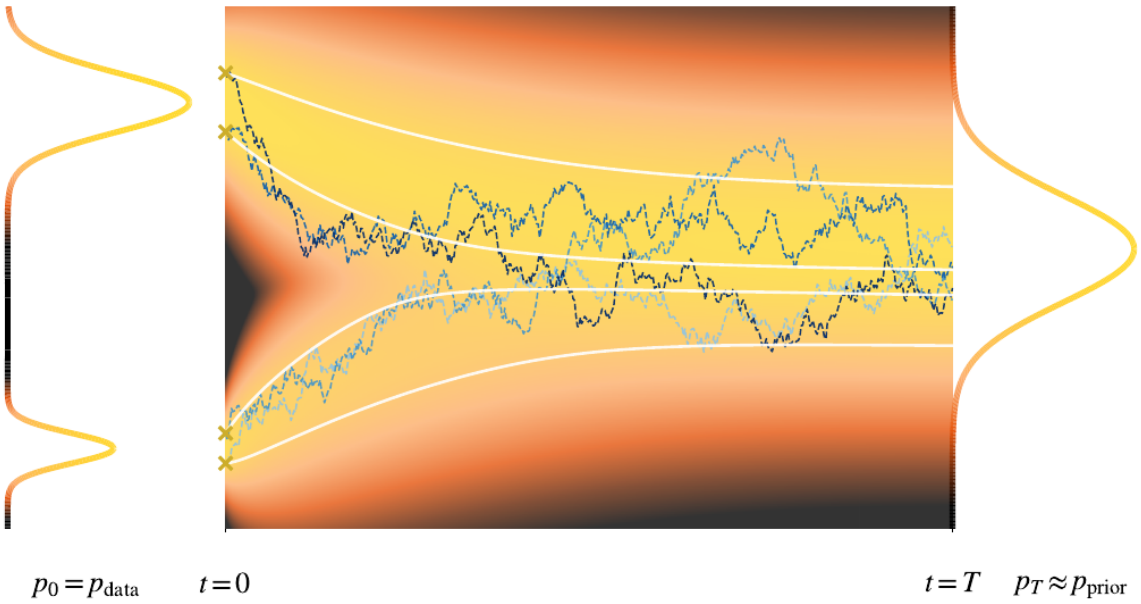


图 4.3: 扩散模型正向过程的一维可视化。从复杂双峰数据分布 $p_0 = p_{\text{data}}$ 抽取初始点（叉号），演化向简单单峰高斯先验 $p_T \approx p_{\text{prior}}$。背景热图显示随时间平滑的边缘密度。比较随机正向 SDE（蓝轨迹）与确定性 PF-ODE（白轨迹）；后者是密度的确定性输运映射，一般不是从单点出发的样本路径均值。来源：作者绘制。

此前离散时间 NCSN（Song and Ermon, 2019）和 DDPM（Sohl-Dickstein et al., 2015; Ho et al., 2020），可以统一为 $[0, T]$ 上由正向 SDE 支配的随机过程：

$$dx(t) = f(x(t), t)\, dt + g(t)\, dw(t), \qquad x(0) \sim p_{\text{data}}. \tag{4.1.3}$$

$f(\cdot, t) : \mathbb{R}^D \to \mathbb{R}^D$ 是漂移，$g(t) \in \mathbb{R}$ 是标量扩散系数，w 是标准 Wiener 过程。它描述干净数据随时间逐渐扰动为噪声。指定 f, g 后，过程完全确定，诱导两族时间依赖密度。

扰动核。 条件律 $p_t(x_t \mid x_0)$ 描述干净样本如何演化为含噪状态。一般漂移可任意依赖 x，常见而便于解析的选择是仿射形式

$$f(x, t) = f(t)x, \tag{4.1.4}$$

$f(t)$ 是通常非正的标量函数。在这一结构下，给定 x_0 的条件过程保持高斯，解相应均值—方差 ODE（Särkkä and Solin, 2019；见第 4.4.3 节）得到

$$\begin{aligned} p_t(x_t \mid x_0) &= \mathcal{N}(x_t; m(t), P(t) I_D), \\ m(t) &= \exp\left(\int_0^t f(u)\, du \right) x_0, \\ P(t) &= \int_0^t \exp\left(2 \int_s^t f(u)\, du \right) g^2(s)\, ds, \end{aligned}$$

初值 $m(0) = x_0$、$P(0) = 0$。这一显式形式允许直接从 x_0 抽取 x_t，无需数值积分 SDE，故称“无需模拟”（simulation-free）。NCSN 与 DDPM 都属于此仿射漂移设定。后续一般理论允许任意漂移，但闭式分析有用时会返回仿射情形。

边缘密度。 对扰动核积分得到

$$p_t(x_t) := \int p_t(x_t \mid x_0) p_{\text{data}}(x_0)\, dx_0, \qquad p_0 = p_{\text{data}}. \tag{4.1.5}$$

恰当选择 $f(t), g(t)$，过程逐渐加噪，最终有效忘记初态影响。T 变大时，$p_T(x_T \mid x_0)$ 不再依赖 x_0，因为其均值演化为

$$m(T) = \exp\left(\int_0^T f(u)\, du\right) x_0 \longrightarrow 0, \qquad T \to \infty,$$

前提是 $f(u)$ 非正，使指数衰减。同时方差增长并稳定为选定先验。于是最初为复杂数据混合的边缘 $p_T(x_T) = \int p_T(x_T \mid x_0) p_{\text{data}}(x_0)\, dx_0$ 收敛于简单的、通常高斯的先验，此时 $p_T(x_T) \approx p_{\text{prior}}(x_T)$ 且 $p_T(x_T \mid x_0) \approx p_{\text{prior}}(x_T)$。正向过程因此将任意数据分布映射到易处理先验，为反转生成提供起点。[4]

4.1.3 用于生成的逆时间随机过程

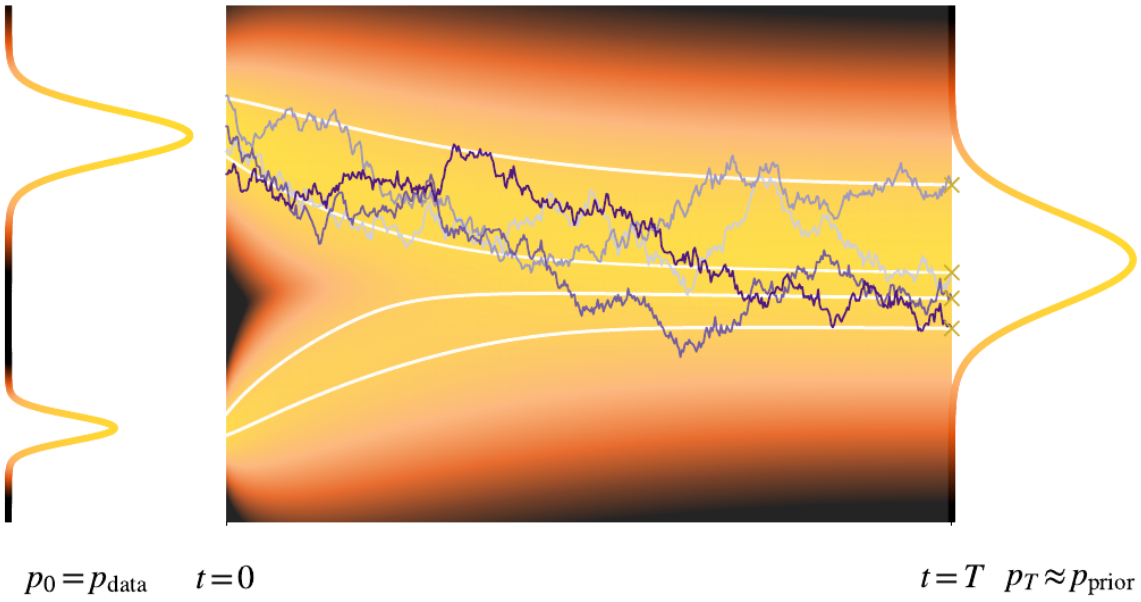


图 4.4: 数据生成的逆时间随机过程。在 $t = T$ 从简单先验抽样（叉号），通过逆时间 SDE 向后演化，在 $t = 0$ 汇成目标双峰数据分布。背景热图显示密度从简单高斯逐渐变为复杂目标。来源：作者绘制。

直观地，生成可通过“反转”正向过程实现：从先验随机点出发，向后演化得到样本。确定性 ODE 自然如此；无随机性时，逆时间只是沿正向的同一路径反方向追踪。[5]SDE 每步都有随机性，单个点可沿许多合理随机轨迹演化，反转更微妙。[6]

[4]译注：仅 $f \le 0$ 不保证积分趋于 $-\infty$，因而不自动保证均值趋零；方差稳定也需关于 f, g 的条件。特别 VE 情形 $f = 0$ 时条件均值仍为 x_0，大噪声先验是相对尺度上的近似，而非上述均值衰减机制。保留原文概述和公式。

[5]严格地，对应于代换 $t \leftrightarrow T - t$ 后求解 ODE。

[6]简单翻转时间不能得到正确逆过程。

虽然单条随机轨迹不可直接这样反转，轨迹分布却可以反转。Anderson (1982) 的基础结果表明，式 (4.1.3) 的时间反转过程 $\{\bar{x}(t)\}_{t\in[0,T]}$[7]仍由良定义 SDE 支配，从 T 演化到 0：

$$\begin{aligned} d\bar{x}(t) &= [f(\bar{x}(t),t) - g^2(t)\nabla_x \log p_t(\bar{x}(t))]\,dt + g(t)\,d\bar{w}(t), \\ \bar{x}(T) &\sim p_{\text{prior}} \approx p_T. \end{aligned} \tag{4.1.6}$$

$\bar{w}(t)$ 是逆时间标准 Wiener 过程，原文定义为 $\bar{w}(t) := w(T-t) - w(T)$。[8]

注。 本章 t 始终是原扩散时钟：0 对应数据、T 对应噪声。因此式 (4.1.6) 从 T 向 0 积分，沿逆过程 $dt < 0$。也可引入向前运行的逆时钟 $s := T - t$；除非另有说明，保持原时钟。

第 4.2.2 节给出高斯数据与线性高斯动力学的具体例子，用基础微积分和线性代数直接推导时间反转公式，无需完整一般理论。随机性 $g \neq 0$ 引入修正项 $-g^2(t)\nabla_x \log p_t$，计入扩散影响，保证逆动力学正确重现正向边缘分布演化，见第 4.2 节。

逆过程为何有效？ 第 4.6.2 节通过 DDPM 变分框架给直观推导；这里补充说明如何从噪声恢复结构。逆过程中仍有 Brownian 噪声，初看似矛盾：正向扩散使数据越来越乱，再注入随机性如何得到集中在数据流形附近的干净样本？关键是噪声不任意加入，扩散项始终与得分驱动漂移耦合。二者平衡：得分引导轨迹走向高密度，噪声提供受控探索而不淹没动力学。

回到式 (3.1.6) 的 Langevin 直觉。$f(t) \equiv 0$ 时，

$$d\bar{x}(t) = -g^2(t)\nabla_x \log p_t(\bar{x}(t))\,dt + g(t)\,d\bar{w}(t).$$

改用 $s = T - t$ ($dt = -ds$)，按分布重新命名 Brownian 运动使 $d\bar{w}(t) = -dw_s$，记 $\bar{x}_s = \bar{x}(T-s)$、$\pi_s = p_{T-s}$，得到

$$\begin{aligned} d\bar{x}_s &= g^2(T-s)\nabla \log \pi_s(\bar{x}_s)\,ds + g(T-s)\,dw_s \\ &= 2\tau(s)\nabla \log \pi_s(\bar{x}_s)\,ds + \sqrt{2\tau(s)}\,dw_s, \qquad\qquad \tau(s) := \tfrac{1}{2}g^2(T-s). \end{aligned}$$

这是原文所称以时变温度 $\tau(s)$ 为特征、针对演化密度 π_s 的 Langevin 形式。Tweedie 公式 (3.3.6) 说明，得分方向指向各时间切片的条件干净信号，漂移持续拉回去噪结构。

关键是沿逆轨迹 $g(t)$ 退火。早期 $s \approx 0$ ($t \approx T$)，$g(T-s)$ 通常较大，噪声强、探索广；随 s 增加，它减小，随机项变弱、得分项占主导，将样本拉向 π_s 高密度区域；到 $s = T$ ($t = 0$)，轨迹集中于数据流形附近。[9]

逆时间 SDE 能力概览。 时间依赖得分 $s(x,t) := \nabla_x \log p_t(x)$ 自然出现于式 (4.1.6)。指定正向系数后，它是唯一未知量；有了得分，逆过程就确定，采样变成用学得得分数值积分。真实得分一般无闭式表达，因此沿第 3 章思路，以神经网络 $s_\phi(x,t)$ 用得分匹配近似，见第 4.3.1 节。代入后，反向动力学完全指定。

---

[7]用横线区别正向 SDE 定义的 $\{x(t)\}$ 与逆过程。

[8]译注：逆过程的驱动 Brownian 运动必须相对于适当逆向滤过理解；一般不能将路径反演后的同一个原始噪声直接当作已满足逆 SDE 适应性条件的驱动噪声。保留原文记法。

[9]译注：这保留原文的启发解释。一般调度未必满足所述单调性；且上述漂移为 $g^2\nabla \log \pi$、扩散为 g，固定时间冻结时并非以 π 为平稳密度的标准平衡 Langevin（后者漂移系数为 $g^2/2$）。这里 π_s 在演化，正确性来自时间反转而非切片平稳性。仅 g 减小也不能独立推出得分项相对占优。

生成从 $x_T \sim p_{\text{prior}}$ 开始，逆向求解到 0。Anderson (1982) 证明正逆过程边缘密度一致，因此 $p_{\text{prior}} \approx p_T$ 时，0 时刻样本近似服从数据分布。第 4.3.2 节将进一步讨论。

4.1.4 用于生成的确定性过程（概率流 ODE）

逆 SDE 注入随机性，可能增加生成样本多样性，但有一个问题：

问题 4.1.1： 必须用式 (4.1.6) 的 SDE 采样吗?

受 Maoutsa et al. (2020) 启发，Song et al. (2020c) 还引入与正向 SDE 边缘分布相同的确定性 ODE。过程 $\{\widetilde{x}(t)\}_{t\in[0,T]}$ 称为概率流 ODE（PF-ODE）：[10]

$$\frac{d}{dt}\widetilde{x}(t) = f(\widetilde{x}(t), t) - \tfrac{1}{2}g^2(t)\nabla_x \log p_t(\widetilde{x}(t)). \tag{4.1.7}$$

与 SDE 类似，用学得得分代替真实得分，从 T 到 0 积分即可生成。具体结果为

$$\widetilde{x}(T) + \int_T^0 \left[f(\widetilde{x}(\tau), \tau) - \tfrac{1}{2}g^2(\tau)\nabla_x \log p_\tau(\widetilde{x}(\tau))\right] d\tau,$$

$\widetilde{x}(T) \sim p_{\text{prior}}$。积分没有可计算闭式，实际依赖数值求解器，如 Euler 法（式 (4.3.6)）。相较逆 SDE，PF-ODE 有两个优点：

- 给定所选端点的相应初值，同一形式 ODE 可从 0 到 T，也可从 T 到 0 积分；这种双向性区别于一般只允许向前时间积分的 SDE；
- 可使用大量成熟、现成的 ODE 数值求解器。

PF-ODE 并非简单删去逆 SDE 的扩散项，其漂移中的 1/2 有原则性来源：选择使 ODE 与正向 SDE 保持相同边缘密度的漂移。保证这一对应的 Fokker–Planck 原理（Øksendal, 2003）将在下一节详述。

4.2 正逆时间 SDE 与 PF-ODE 的边缘匹配

本节将 Fokker–Planck 方程作为支配扩散模型的中心原理。它描述含噪动力学下密度如何演化，是存在随机性时变量替换公式的自然类似物（见附录 B）。从定义边缘 p_t 的正向扩散出发，说明逆 SDE 和 PF-ODE 如何设计成重现同一边缘族，再通过可直接显式计算的高斯例子具体展示。

4.2.1 用 Fokker–Planck 方程保证边缘密度对齐

扩散模型的核心概念是，不同过程可能产生同一边缘分布序列。目标是构造从先验到数据的过程，在时间上对齐边缘，特别在 0 时刻对齐。只要过程易处理、允许高效采样，具体形式居其次。因此有一个根本问题：

问题 4.2.1： 如何保证不同过程产生相同边缘分布?

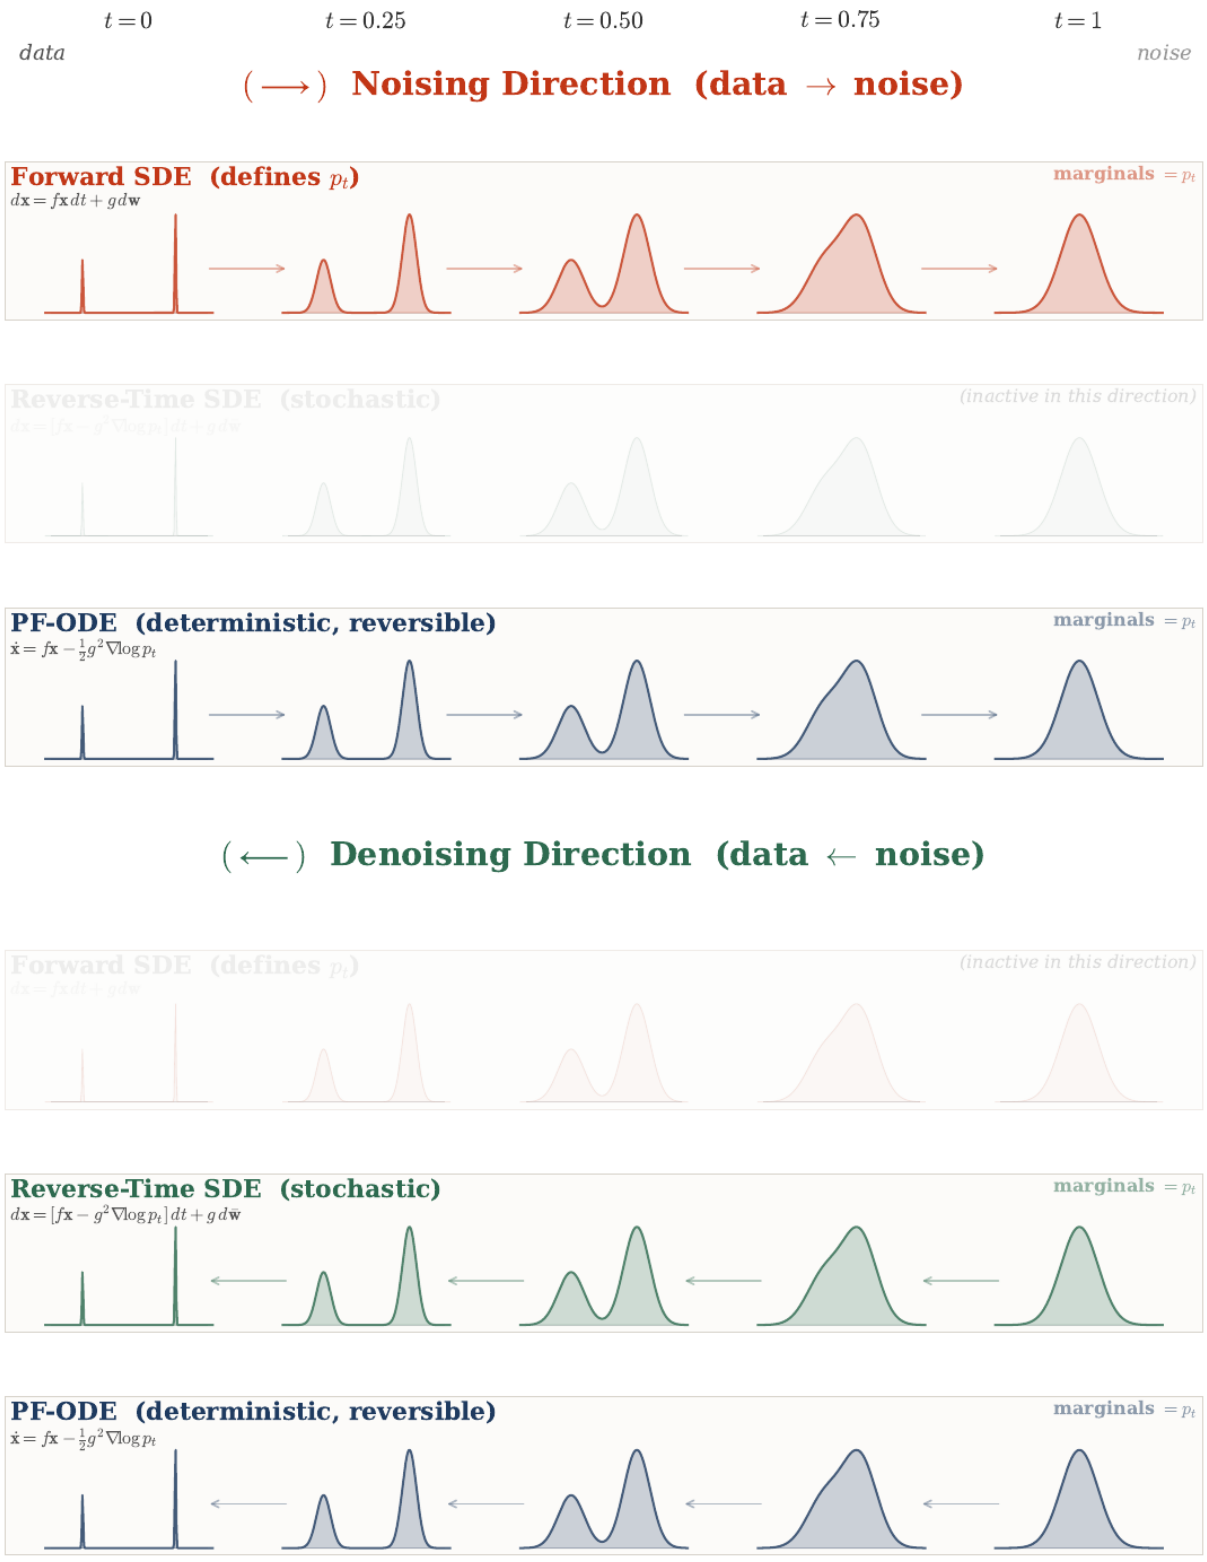


图 4.5: 共享边缘 p_t 的三种动力学。上：加噪方向，正向 SDE 作为参考，定义从数据到高斯先验的边缘；PF-ODE 正向确定性地沿同一边缘路径运行。下：去噪方向，逆时间 SDE 与 PF-ODE 向后运行，按 Fokker–Planck 方程保证的规律，逆序得到同一边缘。前者随机、后者确定。密度快照重复是有意的：单时间边缘相同，样本动力学不同。PF-ODE 两面都出现，因为确定性流可向任一时间方向积分。图内 inactive in this direction 表示 “在该方向不运行”。来源：作者借助 AI 辅助编程绘制。

指定正向 SDE 后，它定义从数据到先验的边缘演化。随后构造逆时间 SDE 与 PF-ODE，使其轨迹边缘精确匹配正向过程。关键在于支配扩散边缘密度演化的 Fokker–Planck 方程，见图 4.5。下列结果（Anderson, 1982; Song et al., 2020c）奠定联系。

定理 4.2.1 (通过 Fokker–Planck 方程对齐边缘)**.** *考虑正向 SDE*

$$dx(t) = f(x(t),t)\,dt + g(t)\,dw(t), \qquad x(0) \sim p_0 = p_{\text{data}}.$$

标准正则条件下，边缘密度满足

$$\begin{aligned}\partial_t p_t(x) &= -\nabla_x \cdot [f(x,t)p_t(x)] + \tfrac{1}{2}g^2(t)\Delta_x p_t(x) \\ &= -\nabla_x \cdot [v(x,t)p_t(x)],\end{aligned} \tag{4.2.1}$$

Δ_x *为 Laplace 算子，* $v(x,t) := f(x,t) - \frac{1}{2}g^2(t)\nabla_x \log p_t(x)$*。同一边缘族* $\{p_t\}_{t\in[0,T]}$ *可由两种动力学实现：*

1. *PF-ODE*: $d\widetilde{x}(t)/dt = v(\widetilde{x}(t),t)$*。从* $\widetilde{x}(0) \sim p_0$ *正向解到* T*，得到* $\widetilde{x}(t) \sim p_t$*；等价地，从* $\widetilde{x}(T) \sim p_T$ *反向解同一 ODE，逆序跟随这些边缘。*

2. *逆时间 SDE*:

$$d\bar{x}(t) = [f(\bar{x}(t),t) - g^2(t)\nabla_x \log p_t(\bar{x}(t))]\,dt + g(t)\,d\bar{w}(t).$$

从 $\bar{x}(T) \sim p_T$ *出发，* $t = T$ *向 0 求解，逆演化中时刻* t *的边缘为* $\bar{x}(t) \sim p_t$*。*

所以即使一个随机、一个确定，二者仍可在各噪声水平具有相同边缘分布。

证明. 证明见附录 D.2.5 节。第 4.6.1 节用概率边缘化给出进一步直觉。 □

固定边缘的多种条件分布。 要理解 PF-ODE 正向输运数据（或逆向输运先验），考虑流映射 $\Psi_{s\to t} : \mathbb{R}^D \to \mathbb{R}^D$，即任意 $s,t \in [0,T]$，从时刻 s 的 x_s 出发在 t 的 ODE 解：

$$\Psi_{s\to t}(x_s) := x_s + \int_s^t v(x_\tau,\tau)\,d\tau, \tag{4.2.2}$$

其中 $v(x,\tau) = f(x,\tau) - \frac{1}{2}g^2(\tau)\nabla_x \log p_\tau(x)$。积分记录沿轨迹累积的净位移。流映射是微分方程、动力系统和连续介质力学的经典术语：将给定动力学下的状态从 s 的位置带到 t 的位置。速度场描述瞬时运动，流映射记录有限区间的累积运动（原文引用键：`arnold1988geometrical`; `chorin1993mathematical`）。[11]全书都采用这个标准数学、物理含义，特别在第 10、11 章讨论快速扩散生成器时。v 满足温和光滑假设时，$\Psi_{s\to t}$ 是光滑双射。[12] 任意 t 的推前密度为

$$p_t^{\text{fwd}}(x_t) := \int \delta(x_t - \Psi_{0\to t}(x_0))p_{\text{data}}(x_0)\,dx_0,$$

[10]用波浪号区别于正逆 SDE 过程；为简洁，之后省略这种区分。

[11]这一物理思想更古老。18 世纪流体力学已经用速度场以及跟随物质粒子研究运动，特别是 Euler 与 Lagrange 的奠基工作（原文引用键：`euler1757fluid`; `lagrange1783fluid`）。

[12]提前说明：PF-ODE 流映射恰好是将 p_s 送到 p_t 的归一化流双射，详见第 5.1 节。区别在于固定正向 SDE 与边缘后，PF-ODE 唯一指定对应速度场；归一化流 / 连续时间归一化流则直接参数化并学习速度。二者依赖同一连续变量替换原理。译注：全区间双射还需解存在唯一、无有限时间爆破等条件，不能仅据局部光滑性保证。原文引用键保留，未猜补出处。

记为 $\Psi_{0\to t}\sharp p_{\text{data}}$，表示流映射下的时刻 t 分布。定理 4.2.1 保证它等于正向 SDE 边缘，即

$$\begin{aligned} p_t(x_t) &= \int p_t(x_t \mid x_0) p_{\text{data}}(x_0)\, dx_0 \\ &= \int \delta(x_t - \Psi_{0\to t}(x_0)) p_{\text{data}}(x_0)\, dx_0. \end{aligned}$$

因此存在无穷多条件分布 $Q_t(x_t \mid x_0)$ 产生同一边缘，例如

- 随机（无需模拟）：$Q_t(x_t \mid x_0) = p_t(x_t \mid x_0)$；
- 确定（需解 ODE）：$Q_t(x_t \mid x_0) = \delta(x_t - \Psi_{0\to t}(x_0))$；
- 混合：$Q_t(x_t \mid x_0) = \lambda p_t(x_t \mid x_0) + (1-\lambda)\delta(x_t - \Psi_{0\to t}(x_0))$，$\lambda \in [0,1]$。

非唯一性来自边缘约束不能唯一确定条件分布，这一概念会在第 5.2.2 和 9.2.3 节再现。特别地，存在一整族与同一 p_t 相容的逆时间 SDE。

观察 4.2.1 (匹配规定的边缘密度)**.** *多个过程可产生同一边缘密度序列，关键是满足 Fokker–Planck 方程。这一洞见赋予从先验到数据或反向设计生成过程的很大灵活性。*

Fokker–Planck 方程位于扩散模型核心，根植于密度的变量替换公式，附录 B 会系统讨论。它不是次要技术细节，会在全书特别是第 5.2 节反复出现。

4.2.2 可计算的例子：高斯动力学的演化

若数据为高斯或高斯混合，得分有闭式表达，是建立扩散直觉的理想设定：仅用基础微积分即可显式推导逆 SDE 和 PF-ODE，无需高级数学工具。本节展示这一可处理情形。

高斯情形逆时间 SDE 的精确计算。 当数据高斯时，可以不依赖 Anderson (1982) 的一般理论直接推导式 (4.1.6)。以一维为例，高维类似。从

$$dx(t) = f(t)x(t)\, dt + g(t)\, dw_t$$

出发，作步长 $\Delta t > 0$ 的小 Euler 步：

$$x_{t+\Delta t} = a x_t + r\epsilon, \qquad a := 1 + f(t)\Delta t, \qquad r := g(t)\sqrt{\Delta t}, \qquad \epsilon \sim \mathcal{N}(0,1).$$

等价地，$x_{t+\Delta t} \mid x_t \sim \mathcal{N}(\cdot; a x_t, r^2)$。当前边缘也是高斯 $x_t \sim \mathcal{N}(\cdot; m_t, s_t^2)$，条件化只涉及两个高斯相乘再归一化，代数初等。由 Bayes 规则，

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) &\propto p(x_{t+\Delta t} \mid x_t) p_t(x_t) \\ &\propto \exp\left(-\frac{(x_t - m_t)^2}{2s_t^2}\right) \exp\left(-\frac{(x_{t+\Delta t} - a x_t)^2}{2r^2}\right). \end{aligned}$$

展开指数中的二次项并合并，

$$\begin{aligned} -2\log p(x_t \mid x_{t+\Delta t}) &= A x_t^2 - 2B x_t + \text{const}, \\ A := \frac{1}{s_t^2} + \frac{a^2}{r^2}, &\qquad B := \frac{m_t}{s_t^2} + \frac{a x_{t+\Delta t}}{r^2}. \end{aligned}$$

A 是精度之和（先验精度与经 a 变换的核精度），B 是相应精度加权目标和。配方为

$$Ax_t^2 - 2Bx_t = A\left(x_t - \frac{B}{A}\right)^2 - \frac{B^2}{A}.$$

后验为高斯，方差 $1/A$、均值 B/A：

$$\mathrm{Var}(x_t \mid x_{t+\Delta t}) = \frac{1}{1/s_t^2 + a^2/r^2},$$
$$\mathbb{E}[x_t \mid x_{t+\Delta t}] = \frac{m_t/s_t^2 + a x_{t+\Delta t}/r^2}{1/s_t^2 + a^2/r^2}.$$

这些闭式已描述任意小步的反向转移。为读出逆 SDE，对小 Δt 展开。代入 $a = 1 + f(t)\Delta t$、$r^2 = g^2(t)\Delta t$，当 $\Delta t \to 0$，$a^2/r^2 \sim 1/(g^2(t)\Delta t)$ 主导精度，所以

$$\mathrm{Var}(x_t \mid x_{t+\Delta t}) = g^2(t)\Delta t + O(\Delta t^2),$$

反向步扩散尺度与正向同为 $g(t)$。均值一阶展开为

$$\mathbb{E}[x_t \mid x_{t+\Delta t}] = x_{t+\Delta t} + \Delta t\left[-\left(f(t) + \frac{g^2(t)}{s_t^2}\right)x_{t+\Delta t} + \frac{g^2(t)}{s_t^2}m_t\right] + O(\Delta t^2).$$

合并均值和方差，单步逆转移核为

$$x_t \mid x_{t+\Delta t} \sim \mathcal{N}\left(x_{t+\Delta t} + \Delta t\left[-\left(f + \frac{g^2}{s_t^2}\right)x_{t+\Delta t} + \frac{g^2}{s_t^2}m_t\right], g^2\Delta t\right) + O(\Delta t^2).$$

它对应从 $t + \Delta t$ 返回 t 的 Euler–Maruyama 更新：

$$x_t - x_{t+\Delta t} = \Delta t\left[-\left(f + \frac{g^2}{s_t^2}\right)x_{t+\Delta t} + \frac{g^2}{s_t^2}m_t\right] + g\sqrt{\Delta t}\epsilon.$$

高斯边缘的得分为 $\partial_x \log p_t(x) = -(x - m_t)/s_t^2$，因此

$$-\left(f + \frac{g^2}{s_t^2}\right)x + \frac{g^2}{s_t^2}m_t = -[fx - g^2\partial_x \log p_t(x)].$$

令 $\Delta t \to 0$，在原扩散时钟下得到

$$d\bar{x}(t) = [f(t)\bar{x}(t) - g^2(t)\partial_x \log p_t(\bar{x}(t))]\,dt + g(t)\,d\bar{w}(t), \qquad t : T \to 0.$$

这恰好匹配式 (4.1.6)，向量形式只需以梯度替代标量导数。

高斯情形 PF-ODE 的精确计算。 同样可以不借助 Fokker–Planck 方程等工具直接推导 PF-ODE，构造性验证它与正逆 SDE 的边缘一致。假设 $x_t \sim \mathcal{N}(\cdot; m_t, s_t^2)$，小确定步写成光滑映射

$$x_{t+\Delta t} = \Phi_{t,\Delta t}(x_t) = x_t + \Delta t v_t(x_t) + O(\Delta t^2).$$

这是关于步长的一阶 Taylor 展开。目标是构造重现相同高斯边缘演化的速度场，简单选择是 $v_t(x) = a_t x + b_t$。仿射动力学保高斯，因此匹配正向 SDE 的均值、方差演化即可确定系数。代回小步，

$$x_{t+\Delta t} = (1 + \alpha_t\Delta t)x_t + \beta_t\Delta t + O(\Delta t^2), \qquad \alpha_t := a_t, \qquad \beta_t := b_t.$$

推前当前高斯并跟踪一阶矩量：

$$\mathbb{E}[x_{t+\Delta t}] = m_t + \Delta t(\alpha_t m_t + \beta_t) + O(\Delta t^2),$$
$$\mathrm{Var}(x_{t+\Delta t}) = s_t^2 + \Delta t(2\alpha_t s_t^2) + O(\Delta t^2).$$

另一方面，正向 SDE 的基础矩公式（式 (4.4.3)）为 $m_t' = f(t)m_t$、$(s_t^2)' = 2f(t)s_t^2 + g^2(t)$。匹配系数得到

$$\alpha_t = f(t) + \frac{g^2(t)}{2s_t^2}, \qquad \beta_t = -\frac{g^2(t)}{2s_t^2}m_t.$$

于是

$$\begin{aligned} x_{t+\Delta t} &= x_t + \Delta t\left[\left(f(t) + \frac{g^2(t)}{2s_t^2}\right)x_t - \frac{g^2(t)}{2s_t^2}m_t\right] + O(\Delta t^2) \\ &= x_t + \Delta t[f(t)x_t - \tfrac{1}{2}g^2(t)\partial_x \log p_t(x_t)] + O(\Delta t^2). \end{aligned}$$

除以步长并取极限，得到

$$x'(t) = f(t)x(t) - \tfrac{1}{2}g^2(t)\partial_x \log p_t(x(t)).$$

漂移为线性加平移，$x(t)$ 仿射依赖 $x(0)$，而仿射映射将高斯送为高斯。依匹配构造，ODE 与正向 SDE 的均值、方差满足同样两条标量方程且初值相同，故任意时刻二者的 $p_t = \mathcal{N}(m_t, s_t^2)$ 完全相同，逆时间 SDE 也如此。

4.3 得分 SDE 的训练与采样

4.3.1 训练

沿第 3 章思路，以时间条件神经网络 $s_\phi = s_\phi(x,t)$ 近似所有 $t \in [0,T]$ 的真实得分，最小化得分匹配目标：

$$\mathcal{L}_{\mathrm{SM}}(\phi;\omega(\cdot)) := \tfrac{1}{2}\mathbb{E}_{t\sim p_{\mathrm{time}}}\mathbb{E}_{x_t\sim p_t}[\omega(t)\|s_\phi(x_t,t) - \nabla_x \log p_t(x_t)\|_2^2],$$

p_{time} 为时间分布，例如 $[0,T]$ 上均匀分布，ω 为时间权重。为避免依赖真实得分，使用式 (3.3.2) 的 DSM。给定 x_0，可通过原式 D.2.4 使用解析条件得分，具体例子见第 4.4 节。损失为

$$\mathcal{L}_{\mathrm{DSM}}(\phi;\omega(\cdot)) := \tfrac{1}{2}\mathbb{E}_t\mathbb{E}_{x_0}\mathbb{E}_{p_t(x_t|x_0)}[\omega(t)\|s_\phi(x_t,t) - \nabla_{x_t}\log p_t(x_t \mid x_0)\|_2^2], \tag{4.3.1}$$

$x_0 \sim p_{\mathrm{data}}$。它是式 (3.4.1) 的连续时间版本，将离散求和换为积分。类似定理 3.3.1，最小化解唯一确定如下。

命题 4.3.1 (DSM 的最小化解)**.** *对几乎处处 $x_t \sim p_t$ 和 $t \in [0,T]$，最小化解满足*

$$s^*(x_t,t) = \mathbb{E}_{x_0\sim p(x_0|x_t)}[\nabla_{x_t}\log p_t(x_t \mid x_0)] = \nabla_{x_t}\log p_t(x_t). \tag{4.3.2}$$

证明. DSM 是最小二乘问题。各时间的最优得分为条件对数密度梯度的条件期望，由 Bayes 规则等于边缘对数密度梯度。详见附录 D.2.6 节。 □

译注：唯一性应在所采样时间分布及正权重覆盖的时间、相应边缘分布的几乎处处意义下理解，且需模型能够表示目标。$t = 0$ 时扰动核可退化，不能不加条件把非退化条件密度得分直接延伸到该端点。

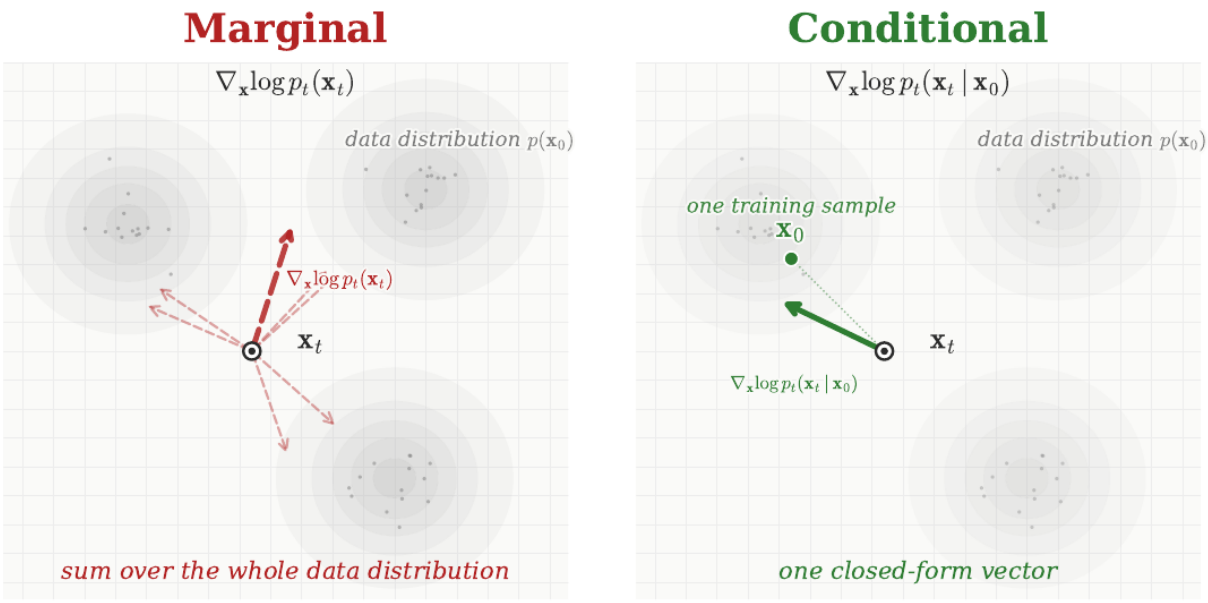


图 4.6: 去噪得分匹配技巧。左：固定 x_t 时，边缘得分指向含噪样本更可能出现的区域，直接计算需要合并所有可能产生它的干净样本贡献，通常很困难。右：训练时已知干净 x_0，高斯污染的条件得分有闭式表达，提供一个简单回归向量。跨训练实例，这些条件向量平均为边缘得分，因此无需直接以难计算的全数据平均为回归目标。图内 Marginal / Conditional 为“边缘 / 条件”，底部文字为“对整个数据分布求和 / 一个闭式向量”。来源：作者借助 AI 辅助编程绘制。

4.3.2 采样与推断

学得 $s_{\phi^\times}(x,t) \approx \nabla_x \log p_t(x)$ 后，将逆 SDE 式 (4.1.6) 和 PF-ODE 式 (4.1.7) 的真实得分换为学得替代。为明确，分别记过程为 $x^{\mathrm{SDE}}_{\phi^\times}(t)$ 与 $x^{\mathrm{ODE}}_{\phi^\times}(t)$；后文将省略区分。[13]

经验逆时间 SDE。 代入得分模型，得到生成用参数化 SDE：

$$dx^{\mathrm{SDE}}_{\phi^\times}(t) = \left[f(x^{\mathrm{SDE}}_{\phi^\times}(t),t) - g^2(t) s_{\phi^\times}(x^{\mathrm{SDE}}_{\phi^\times}(t),t) \right] dt + g(t)\, d\bar{w}(t). \tag{4.3.3}$$

先抽取 $x_T \sim p_{\mathrm{prior}}$，再从 T 向 0 数值求解。标准 Euler–Maruyama 给出 $\Delta t > 0$ 的更新：

$$x_{t-\Delta t} \leftarrow x_t - [f(x_t,t) - g^2(t) s_{\phi^\times}(x_t,t)]\Delta t + g(t)\sqrt{\Delta t}\epsilon, \tag{4.3.4}$$

$\epsilon \sim \mathcal{N}(0,I)$。迭代得到 $x^{\mathrm{SDE}}_{\phi^\times}(0)$。得分准确时，生成分布 $p^{\mathrm{SDE}}_{\phi^\times}(\cdot;0) \approx p_{\mathrm{data}}$。[14]VP 构造中，第 2 章 DDPM 采样式 (2.2.14) 与上式具有相同连续时间逆 SDE 极限，见第 4.4 节。

经验 PF-ODE。 它连接先验与数据，可进行采样、编码及精确似然计算，下面分别介绍。

1. **用 PF-ODE 采样。**将式 (4.1.7) 的真实得分替换为模型：

$$\frac{d}{dt} x^{\mathrm{ODE}}_{\phi^\times}(t) = f(x^{\mathrm{ODE}}_{\phi^\times}(t),t) - \tfrac{1}{2} g^2(t) s_{\phi^\times}(x^{\mathrm{ODE}}_{\phi^\times}(t),t). \tag{4.3.5}$$

[13]这样可在本节之后简化记号。

[14]理论精度取决于 p_T 与先验差距（通常可忽略）、模型训练误差和数值离散误差（原文引用键 `wang2024evaluating`; De Bortoli, 2022）。此处不研究正式误差界。

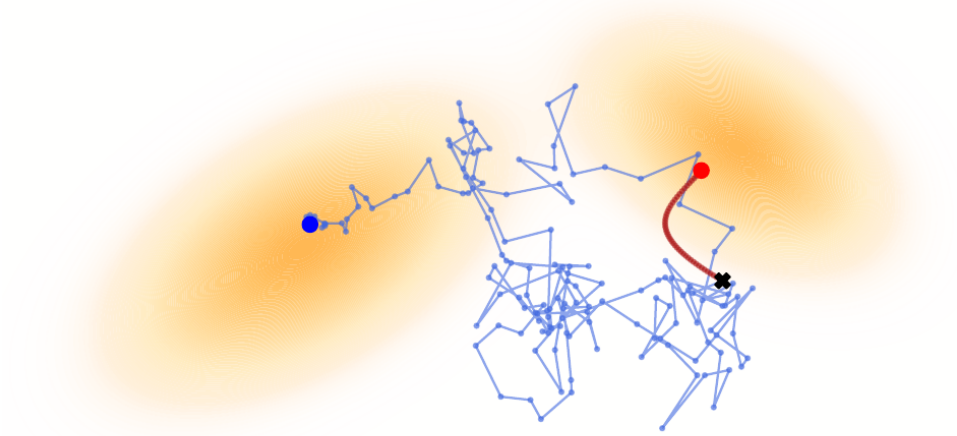


图 4.7: 得分 SDE 采样的二维示意。正向过程 $dx(t) = \sqrt{2t}\, dw(t)$，$f = 0$、$g(t) = \sqrt{2t}$，将双峰高斯混合演化到 $p_T \approx \mathcal{N}(0, T^2 I)$。蓝色为逆 SDE（式 (4.3.4)）轨迹，红色为 PF-ODE（式 (4.3.6)）轨迹。均从先验随机点（深色叉号）出发，随 $t \to 0$ 走向数据支集。来源：作者绘制。

抽取 $x_T \sim p_{\text{prior}}$，从 T 到 0 数值求解，等价于近似积分

$$x_{\phi^\times}^{\text{ODE}}(0) = x_T + \int_T^0 \left[f(x_{\phi^\times}^{\text{ODE}}(\tau), \tau) - \tfrac{1}{2} g^2(\tau) s_{\phi^\times}(x_{\phi^\times}^{\text{ODE}}(\tau), \tau) \right] d\tau.$$

结果分布 $p_{\phi^\times}^{\text{ODE}}(\cdot; 0)$ 近似数据分布。Euler 法在 $\tau \in [t - \Delta t, t]$ 将被积场近似为 t 的值，给出

$$x_{t-\Delta t} \leftarrow x_t - [f(x_t, t) - \tfrac{1}{2} g^2(t) s_{\phi^\times}(x_t, t)] \Delta t. \tag{4.3.6}$$

洞见 4.3.1 (生成 $\Longleftrightarrow$ 求解 ODE / SDE)**.** *扩散模型采样从根本上等价于求解相应概率流 ODE 或逆时间 SDE。*

这清楚解释了问题 3.5.1 中的缓慢采样：数值求解器本质上迭代运行，常需许多步骤准确近似轨迹。[15]但 PF-ODE 也允许利用加速数值求解器的丰富研究，第 9 章将重点讨论。

2. **用 PF-ODE 反演**。与 SDE 不同，同一式 (4.3.5) 可正向（0 到 T）或反向求解。正向时，流将数据映射为各 $t \in [0, T]$ 的含噪潜在表示，扮演编码器。它支持图像转换、编辑等可控生成应用（Mokady et al., 2023; Su et al., 2022）。

3. **用 PF-ODE 计算对数似然**。式 (5.1.9) 说明，沿 ODE 轨迹对数密度变化由速度场散度决定。定义学得速度

$$v_{\phi^\times}(x, t) := f(x, t) - \tfrac{1}{2} g^2(t) s_{\phi^\times}(x, t).$$

[15]例如 DDPM 和得分 SDE 通常用 1000 次函数求值生成样本。

若 $dx(t)/dt = v_{\phi^\times}(x(t), t)$，则

$$\frac{d}{dt} \log p^{\mathrm{ODE}}_{\phi^\times}(x(t); t) = -\nabla_x \cdot v_{\phi^\times}(x(t), t).$$

为计算观测 x_0 的似然，从 0 正向运行到 T，映射到模型密度为易处理先验的终点。定义

$$\delta(t) := \log p^{\mathrm{ODE}}_{\phi^\times}(x(t); t) - \log p^{\mathrm{ODE}}_{\phi^\times}(x_0; 0),$$

$\delta(0) = 0$。联合求解状态与密度变化：

$$\frac{d}{dt}\begin{bmatrix} x(t) \\ \delta(t) \end{bmatrix} = \begin{bmatrix} v_{\phi^\times}(x(t), t) \\ -\nabla_x \cdot v_{\phi^\times}(x(t), t) \end{bmatrix}, \qquad \begin{bmatrix} x(0) \\ \delta(0) \end{bmatrix} = \begin{bmatrix} x_0 \\ 0 \end{bmatrix}. \tag{4.3.7}$$

终点密度为 $p_{\mathrm{prior}}(x(T))$，因此

$$\begin{aligned} \log p^{\mathrm{ODE}}_{\phi^\times}(x_0; 0) &= \log p_{\mathrm{prior}}(x(T)) - \delta(T) \\ &= \log p_{\mathrm{prior}}(x(T)) + \int_0^T \nabla_x \cdot v_{\phi^\times}(x(t), t)\, dt. \end{aligned}$$

同一 PF-ODE 因而既生成和反演，也通过连续变量替换计算似然。

4.4 SDE 的具体实例

Song et al. (2020c) 根据方差演化，将正向 SDE 漂移和扩散分为三类。这里只关注两种常用类型：方差爆炸（VE）与方差保持（VP）SDE。可设计自定义调度，但会显著影响实际表现。表 4.1 总结二者。

表 4.1: 正向 SDE 总结

	VE SDE	VP SDE
$f(x,t)$	0	$-\frac{1}{2}\beta(t)x$
$g(t)$	$\sqrt{d\sigma^2(t)/dt}$	$\sqrt{\beta(t)}$
SDE	$dx(t) = g(t)\, dw(t)$	$dx(t) = -\frac{1}{2}\beta(t)x(t)\, dt + \sqrt{\beta(t)}\, dw(t)$
$p_t(x_t \mid x_0)$	$\mathcal{N}(x_t; x_0, (\sigma^2(t) - \sigma^2(0))I)$	$\mathcal{N}\Big(x_t; x_0 e^{-\frac{1}{2}\int_0^t \beta(\tau)d\tau}, (1 - e^{-\int_0^t \beta(\tau)d\tau})I\Big)$
p_{prior}	$\mathcal{N}(0, \sigma^2(T)I)$	$\mathcal{N}(0, I)$

4.4.1 VE SDE

VE SDE 的漂移为零，扩散为 $g(t) = \sqrt{d\sigma^2(t)/dt}$。因此

$$dx(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}\, dw(t). \tag{4.4.1}$$

第 4.4.3 节结果给出扰动核

$$p_t(x_t \mid x_0) = \mathcal{N}(x_t; x_0, (\sigma^2(t) - \sigma^2(0))I).$$

假设 σ 在 $[0,T]$ 递增且 $\sigma^2(T) \gg \sigma^2(0)$，选择先验 $p_{\text{prior}} := \mathcal{N}(0, \sigma^2(T)I)$。典型 NCSN 设计为

$$\sigma(t) := \sigma_{\min} \left(\frac{\sigma_{\max}}{\sigma_{\min}}\right)^t, \qquad t \in (0,1],$$

$\sigma_{\min}, \sigma_{\max}$ 预先指定，即按几何序列设计方差。NCSN 因而是 VE SDE 的离散版本，见第 4.1 节。

4.4.2 VP SDE

令 $\beta : [0,T] \to \mathbb{R}_{\geq 0}$ 非负。VP 的漂移 $f(x,t) = -\frac{1}{2}\beta(t)x$，扩散 $g(t) = \sqrt{\beta(t)}$，因此

$$dx(t) = -\tfrac{1}{2}\beta(t)x(t)\,dt + \sqrt{\beta(t)}\,dw(t). \tag{4.4.2}$$

第 4.4.3 节给出

$$p_t(x_t \mid x_0) = \mathcal{N}\Big(x_t; x_0 e^{-\frac{1}{2}\int_0^t \beta(\tau)d\tau}, (1 - e^{-\int_0^t \beta(\tau)d\tau})I\Big),$$
$$p_{\text{prior}} := \mathcal{N}(0, I).$$

已知均值、协方差的高斯核，可用原式 D.2.5 计算其得分。经典例子 DDPM 采用

$$\beta(t) := \beta_{\min} + t(\beta_{\max} - \beta_{\min}), \qquad t \in [0,1],$$

两端常数预先指定。DDPM 因而可解释为 VP SDE 的离散化。

4.4.3 （可选）如何导出扰动核？

若正向漂移为标量时间函数乘 x，SDE 为线性：

$$dx(t) = f(t)x(t)\,dt + g(t)\,dw(t).$$

即使初始数据非高斯，给定 x_0 的条件过程仍高斯。$t > 0$ 时，

$$p_t(x_t \mid x_0) = \mathcal{N}(x_t; m(t), P(t)I_D),$$
$$m(t) = \mathbb{E}[x_t \mid x(0) = x_0], \qquad P(t)I_D = \mathrm{Cov}[x_t \mid x(0) = x_0].$$

一、二阶矩满足（Särkkä and Solin, 2019）

$$\frac{dm(t)}{dt} = f(t)m(t), \qquad \frac{dP(t)}{dt} = 2f(t)P(t) + g^2(t), \tag{4.4.3}$$

前提是初始均值和方差有限。两条 ODE 线性，可用积分因子得到闭式。给定 x_0，

$$m(t) = \mathcal{E}(0 \to t)x_0, \qquad P(t) = \int_0^t \mathcal{E}^2(s \to t)g^2(s)\,ds, \tag{4.4.4}$$

$m(0) = x_0$、$P(0) = 0$，其中 $\mathcal{E}(s \to t) := \exp(\int_s^t f(u)\,du)$ 捕捉漂移的累积影响。因此转移核也有闭式表达。条件协方差在独立坐标 Wiener 过程及扩散 $g(t)I_D$ 下为何各向同性，以及矩方程的推导，留到附录 C.1.5 节用 Itô 微积分说明。

例：VE 转移核。 $f=0$、$g(t)=\sqrt{d\sigma^2(t)/dt}$ 时，

$$\frac{dm(t)}{dt}=0, \qquad m(0)=x_0, \qquad m(t)=x_0,$$
$$\frac{dP(t)}{dt}=\frac{d\sigma^2(t)}{dt}, \qquad P(0)=0, \qquad P(t)=\sigma^2(t)-\sigma^2(0).$$

因此 $p_t(x_t\mid x_0)=\mathcal{N}(x_t;x_0,(\sigma^2(t)-\sigma^2(0))I_D)$。

例：VP 转移核。 定义 $B(t):=\int_0^t\beta(s)\,ds$，有

$$\frac{dm}{dt}=-\tfrac{1}{2}\beta(t)m(t), \qquad m(t)=e^{-B(t)/2}x_0,$$
$$\frac{dP}{dt}=-\beta(t)P(t)+\beta(t).$$

乘积分因子 $e^{B(t)}$，

$$\frac{d}{dt}[P(t)e^{B(t)}]=\beta(t)e^{B(t)}.$$

积分得 $P(t)=1-e^{-B(t)}$，协方差 $\mathbf{P}(t)=P(t)I_D=(1-e^{-B(t)})I_D$，最终闭式核为

$$p_t(x_t\mid x_0)=\mathcal{N}\big(x_t;\underbrace{e^{-B(t)/2}x_0}_{m(t)},\underbrace{(1-e^{-B(t)})I_D}_{P(t)I_D}\big), \qquad B(t)=\int_0^t\beta(s)\,ds.$$

4.5 通过累积扰动核直接理解扩散

DDPM 与得分 SDE 常从局部时间加噪规则介绍：前者给离散转移 $p(x_t\mid x_{t-\Delta t})$，后者给连续时间 SDE。但训练中尤其有用的是累积扰动核 $p_t(x_t\mid x_0)$，直接描述给定原始数据的时刻 t 分布。这恰好自然出现于 DDPM 和连续时间去噪目标式 (2.2.8)、(4.3.1)。

因此有互补视角：不从局部加噪再推核，而直接指定累积核。对下述线性高斯过程，容许的累积核确定相应线性 SDE，反之亦然。它显式给出各时间信号、噪声量，直接联系训练目标，也搭建通向第 5 章流匹配概率路径视角的桥梁。

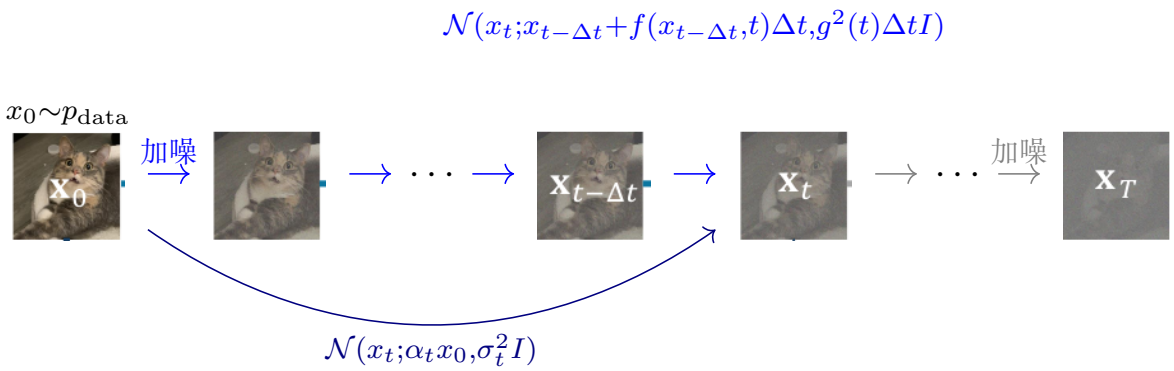


图 4.8: 同一仿射正向过程的两种视角。容许的仿射扩散调度下，通过连续时间线性 SDE 逐步加噪，与直接指定式 (4.5.1) 的累积扰动核，描述同一条件分布 $p_t(x_t\mid x_0)$。原图 Add noise 已译为“加噪”。来源：作者绘制；节点照片保留源裁片，箭头与核用 tikz-cd 重建。

一般仿射正向过程。 定义

$$p_t(x_t \mid x_0) := \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I), \tag{4.5.1}$$

其中 $x_0 \sim p_{\text{data}}$，α_t, σ_t 为 $[0,T]$ 上非负标量函数。标准正向设定取 $\alpha_0 = 1$、$\sigma_0 = 0$，从数据精确开始；在使用相应比值的 $t \in (0,T]$ 假设二者严格正。等价地，$x_t = \alpha_t x_0 + \sigma_t \epsilon$，$\epsilon \sim \mathcal{N}(0, I)$。它包括熟悉的路径：

- VE（NCSN）：$\alpha_t \equiv 1$，σ_t 随时间增加；
- VP（DDPM）：$\alpha_t^2 + \sigma_t^2 = 1$；
- 线性高斯插值：$\alpha_t = 1 - t$、$\sigma_t = t$，$t \in [0,1]$，即数据到噪声时间约定下流匹配和 Rectified Flow 常用的线性路径。

4.5.1 与得分 SDE 的联系

先指定累积核再恢复 SDE 系数，往往比从漂移扩散求矩 ODE 更直观。容许的仿射调度对应线性形式

$$dx(t) = \underbrace{f(t)x(t)}_{f(x(t),t)}\, dt + g(t)\, dw(t),$$

$f, g : [0,T] \to \mathbb{R}$。[16]系数可从 α, σ 解析恢复，但不是每一组选择都定义有效扩散：g^2 必须非负。等价地，线性高斯设定中的信噪比不能随时间增加。

引理 4.5.1 (正向扰动核 $\Longleftrightarrow$ 线性 SDE)**.** *假设 $\alpha_0 = 1$、$\sigma_0 = 0$，$t \in (0,T]$ 上 $\alpha_t, \sigma_t > 0$ 且可微。定义 $\lambda_t := \log(\alpha_t/\sigma_t)$。给定 $x_t = \alpha_t x_0 + \sigma_t \epsilon$、$\epsilon \sim \mathcal{N}(0, I)$，存在具有相同条件核的线性 SDE，当且仅当系数*

$$\begin{aligned} f(t) &= \frac{d}{dt} \log \alpha_t, \\ g^2(t) &= \frac{d\sigma_t^2}{dt} - 2\left(\frac{d}{dt}\log\alpha_t\right)\sigma_t^2 = -2\sigma_t^2 \frac{d\lambda_t}{dt} \end{aligned} \tag{4.5.2}$$

满足 $g^2(t) \geq 0$，等价于 λ_t 非增。反之，若线性 SDE 的条件核为该高斯形式，其系数必满足上式。

证明. 由第 4.4.3 节，匹配均值 ODE $m' = fm$、协方差 ODE $\mathbf{P}' = 2f\mathbf{P} + g^2 I$，取 $m(t) = \alpha_t x_0$、$\mathbf{P}(t) = \sigma_t^2 I$ 即得。 □

注。 若要终端条件分布独立于 x_0 且等于规定高斯先验，需 $\alpha_T = 0$、σ_T^2 等于先验方差。但

$$\alpha_t = \exp\left(\int_0^t f(u)\, du\right),$$

[16]译注：原文在此把一般线性 SDE 指向式 (4.4.2)，但该式是特定 VP SDE；一般形式见本节所列公式。这里只说明原定位不准确，不改变公式。

有限终点实现零值要求 $\int_0^T f(u)\,du = -\infty$，漂移收缩必须在终点附近变奇异，$f$ 不能在整个有限区间有界。扩散系数满足 $g^2(t) = (\sigma_t^2)' - 2(\alpha_t'/\alpha_t)\sigma_t^2$。通常规则调度下，若 σ_t^2 趋于有限非零值、其导数有界且 $\alpha_t'/\alpha_t \to -\infty$，还得到 $g^2(t) \to \infty$。更一般的行为取决于具体调度。

如果 f, g 在有限区间均有界，则 $\alpha_T > 0$，不能精确忘记初态。实践中选取残余依赖可忽略、$p_T \approx p_{\text{prior}}$ 的终点，或采用 $\alpha_t \to 0$ 的无限时间表述。

因此，指定局部线性 SDE 与指定累积核在数学上等价，文献中交替使用这两种视角。

观察 4.5.1. *对有效仿射扩散调度，可以指定由 α_t, σ_t 给出的累积核，也可以指定由 $f(t), g(t)$ 给出的对应线性 SDE；两种描述等价。*

4.5.2 与变分扩散模型的联系

回顾 DDPM 中由 Bayes 规则导出的核心恒等式：

$$p(x_{t-\Delta t} \mid x_t, x) = p(x_t \mid x_{t-\Delta t}) \frac{p_{t-\Delta t}(x_{t-\Delta t} \mid x)}{p_t(x_t \mid x)}, \tag{4.5.3}$$

适用于任意 x，通常 $x \sim p_{\text{data}}$。反向条件核是建模核心，提供可计算训练目标与高效采样。虽然 DDPM 常先定义增量核，累积核对先验和损失设计往往更易解释、更实用。

推导转移核。 扩展到连续时间，令 $0 \le t < s \le T$，给定累积核，利用正向 $p(x_s \mid x_t)$ 作中间量，应用式 (4.5.3) 得反向条件核。[17]下列引理推广引理 2.2.2，不再要求 $\alpha_t^2 + \sigma_t^2 = 1$。

引理 4.5.2 (反向条件转移核)**.** 令 $0 \le t < s \le T$。则

$$p(x_t \mid x_s, x) = \mathcal{N}(x_t; \mu(x_s, x; s, t), \sigma^2(s,t) I),$$

其中

$$\begin{aligned} \mu(x_s, x; s, t) &:= \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2} x_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2} x, \\ \sigma^2(s,t) &:= \sigma_{s|t}^2 \frac{\sigma_t^2}{\sigma_s^2}, \end{aligned} \tag{4.5.4}$$

$\alpha_{s|t} := \alpha_s/\alpha_t$，$\sigma_{s|t}^2 := \sigma_s^2 - \alpha_{s|t}^2 \sigma_t^2$。

证明. 先计算正向核：

$$p(x_s \mid x_t) = \mathcal{N}(x_s; \alpha_{s|t} x_t, \sigma_{s|t}^2 I). \tag{4.5.5}$$

再由 Bayes 规则求逆。涉及的分布均高斯，可直接计算；细节见 Kingma et al. (2021) 的附录 A。 □

虽然局部核与累积核在理论上等价，后者常居中心位置。式 (4.5.5) 主要用于求闭式逆核，近期工作（Kingma et al., 2021）因而偏好直接指定累积核，使其清晰易解释。

[17]原文称此恒等式可把 s 视为“一般较早时刻”扩展到连续时间。译注：在本段约定 $t < s$ 下，s 是正向时钟中较晚、逆向采样中较早到达的时刻；保留并明确其方向。

逆过程建模、训练与采样。 第 2.2 节的建模框架与 ELBO 式 (2.2.13) 在推广设定下仍适用。为明确，沿 Kingma et al. (2021) 使用 x 预测 $x_\phi(x_s, s)$；噪声预测仍等价，因为

$$x_s = \alpha_s x_\phi(x_s, s) + \sigma_s \epsilon_\phi(x_s, s), \qquad\qquad x_s \sim q_s.$$

译注： 原文在此使用未另定义的 q_s，按上下文应指含噪边缘；保留记号，待原文勘误裁定。

建模与扩散损失。 类似 DDPM，用可学习预测代替条件均值中的真实干净信号，

$$p_\phi(x_t \mid x_s) := \mathcal{N}(x_t; \mu_\phi(x_s, s, t), \sigma^2(s,t) I), \tag{4.5.6}$$

均值为

$$\mu_\phi(x_s, s, t) = \frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2} x_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2} x_\phi(x_s, s).$$

给定正向核，扩散损失中的 KL 化为加权回归：

$$\begin{aligned} D_{\mathrm{KL}}(p(x_t \mid x_s, x_0) \| p_\phi(x_t \mid x_s)) &= \frac{\|\mu(x_s, x_0; s, t) - \mu_\phi(x_s, s, t)\|_2^2}{2\sigma^2(s,t)} \\ &= \tfrac{1}{2}(\mathrm{SNR}(t) - \mathrm{SNR}(s)) \|x_0 - x_\phi(x_s, s)\|_2^2, \end{aligned} \tag{4.5.7}$$

其中 $x_s = \alpha_s x_0 + \sigma_s \epsilon$，$x_0 \sim p_{\mathrm{data}}$、$\epsilon \sim \mathcal{N}(0, I)$，$\mathrm{SNR}(s) := \alpha_s^2/\sigma_s^2$。

注。 Kingma et al. (2021) 研究 $t \to s$ 的连续时间极限，得到

$$\mathcal{L}_{\mathrm{VDM}}^{\infty}(x_0) = -\tfrac{1}{2}\mathbb{E}_{s, \epsilon \sim \mathcal{N}(0,I)}[\mathrm{SNR}'(s) \|x_0 - x_\phi(x_s, s)\|_2^2].$$

它还引入可学习噪声调度，并推广到连续数据之外；这些扩展超出当前讨论范围。[18]

采样。 与 DDPM 类似，从参数核采样：

$$x_t = \underbrace{\frac{\alpha_{s|t}\sigma_t^2}{\sigma_s^2} x_s + \frac{\alpha_t \sigma_{s|t}^2}{\sigma_s^2} x_{\phi^\times}(x_s, s)}_{\mu_{\phi^\times}(x_s, t, s)} + \sigma_{s|t} \frac{\sigma_t}{\sigma_s} \epsilon_s, \qquad\qquad \epsilon_s \sim \mathcal{N}(0, I). \tag{4.5.8}$$

译注： 原式下括号中的均值参数次序写为 (x_s, t, s)，与式 (4.5.6) 的 (x_s, s, t) 相反；显式系数保留原文，应按它们判断实际转移。当 $t = 0$ 时方差退化，KL 回归及采样边界须如第 2 章重建项一样单独处理。

4.6 （可选）通过边缘化与 Bayes 规则理解 Fokker–Planck 方程和逆时间 SDE

本节从概率视角解释二者的结构，用边缘化和 Bayes 规则等基础工具，说明随机过程统计表述与微分方程的联系。这里的“推导”不是严格数学证明，而是传达底层联系的启发论证。

[18] 译注：原文期望下标将 s, ϵ 并列于 $\mathcal{N}(0, I)$，但 s 是时间、ϵ 是高斯噪声，二者取样律需区分；这里保留原式，不猜定时间分布。

4.6.1 从转移核边缘化得到 Fokker–Planck 方程

给定式 (4.1.2) 的正向高斯转移与边缘 $p_t(x_t), p_{t+\Delta t}(x_{t+\Delta t})$，目标是导出控制边缘时间演化的方程。

变量替换。 Markov 性给出 Chapman–Kolmogorov 方程：

$$p_{t+\Delta t}(x) = \int \mathcal{N}(x; y + f(y,t)\Delta t, g^2(t)\Delta t I) p_t(y)\, dy.$$

令 $u := y + f(y,t)\Delta t$，使高斯以 u 为中心。小步长时映射可逆，

$$\begin{aligned} y &= u - f(u,t)\Delta t + O(\Delta t^2), \\ \det \frac{\partial y}{\partial u} &= 1 - (\nabla_u \cdot f)(u,t)\Delta t + O(\Delta t^2). \end{aligned}$$

变量替换给出

$$\begin{aligned} p_{t+\Delta t}(x) = \int & \mathcal{N}(x; u, g^2(t)\Delta t I) \\ & \times \left[p_t(u) - \Delta t f(u,t) \cdot \nabla_u p_t(u) - \Delta t (\nabla_u \cdot f)(u,t) p_t(u) \right] du + O(\Delta t^2). \end{aligned}$$

Taylor 展开。 任意光滑 $\varphi : \mathbb{R}^D \to \mathbb{R}$，$\sigma > 0$，$z \sim \mathcal{N}(0, I)$，有 Taylor—高斯平滑公式

$$\begin{aligned} \int \mathcal{N}(x; u, \sigma^2 I)\varphi(u)\, du &= \mathbb{E}[\varphi(x + \sigma z)] \\ &= \varphi(x) + \tfrac{1}{2}\sigma^2 \Delta_x \varphi(x) + O(\sigma^4), \end{aligned}$$

因为

$$\varphi(x + \sigma z) = \varphi(x) + \sigma \nabla_x \varphi(x) \cdot z + \tfrac{1}{2}\sigma^2 z^\top \nabla_x^2 \varphi(x) z + O(\sigma^3),$$

且 $\mathbb{E}[z] = 0$、$\mathbb{E}[zz^\top] = I$。分别取 $\varphi = p_t$、$f \cdot \nabla_u p_t$ 和 $(\nabla_u \cdot f) p_t$，并用 $\sigma^2 = g^2(t)\Delta t$，得到

$$\begin{aligned} p_{t+\Delta t}(x) - p_t(x) &= -\Delta t f(x,t) \cdot \nabla_x p_t(x) - \Delta t (\nabla_x \cdot f)(x,t) p_t(x) \\ &\quad + \tfrac{1}{2} g^2(t) \Delta t \Delta_x p_t(x) + O(\Delta t^2) \\ &= -\Delta t \nabla_x \cdot (f(x,t) p_t(x)) + \tfrac{1}{2} g^2(t) \Delta t \Delta_x p_t(x) + O(\Delta t^2). \end{aligned}$$

除以步长再取极限，即得 Fokker–Planck 方程。附录 C.1.4 节以 Itô 推导补充这一离散时间图景。[19]

4.6.2 逆时间 SDE 为什么具有这一形式？

严格推导技术性很强，需要深入 Fokker–Planck 方程性质。但可通过 Bayes 定理直观理解式 (4.1.6) 为什么出现得分函数。[20]

[19] 译注：$O(\sigma^4)$ 的期望余项需足够高阶光滑性、可积界和对奇数阶项的对称抵消；单列 $O(\sigma^3)$ 的逐点 Taylor 余项尚不足以直接证明这一阶数。原文已将整节限定为启发论证。

[20] 此推导受原文链接的这篇文章启发；链接从冻结 PDF 物理 134 页注 14 提取，未替换为猜测来源。

用 Bayes 规则反转。 先考虑离散逆转移，再令步长趋零：

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) &= p(x_{t+\Delta t} \mid x_t)\frac{p_t(x_t)}{p_{t+\Delta t}(x_{t+\Delta t})} \\ &= p(x_{t+\Delta t} \mid x_t)\exp(\log p_t(x_t) - \log p_{t+\Delta t}(x_{t+\Delta t})). \end{aligned} \tag{4.6.1}$$

正向核假设如式 (4.1.2)。

Taylor 展开。 在 (x_t, t) 附近对空间和时间作一阶展开：

$$\begin{aligned} \log p_{t+\Delta t}(x_{t+\Delta t}) = \log p_t(x_t) &+ \nabla_x \log p_t(x_t)\cdot(x_{t+\Delta t} - x_t) \\ &+ \frac{\partial \log p_t(x_t)}{\partial t}\Delta t + O(\|h\|_2^2), \end{aligned}$$

$h := (x_{t+\Delta t} - x_t, \Delta t)$。于是

$$\begin{aligned} \log p_t(x_t) - \log p_{t+\Delta t}(x_{t+\Delta t}) = &-\nabla_x \log p_t(x_t)\cdot(x_{t+\Delta t} - x_t) \\ &- \frac{\partial \log p_t(x_t)}{\partial t}\Delta t + O(\|h\|_2^2). \end{aligned} \tag{4.6.2}$$

扩散增量为 $O_p(\sqrt{\Delta t})$，二阶空间项一般为 $O_p(\Delta t)$。因此以下计算只能理解为主导阶启发。

代入逆转移。 将正向核和式 (4.6.2) 代入 Bayes 公式：

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) = &\frac{1}{(2\pi g^2(t)\Delta t)^{D/2}}\exp\left(-\frac{\|x_{t+\Delta t} - x_t - f(x_t,t)\Delta t\|_2^2}{2g^2(t)\Delta t}\right) \\ &\times \exp\left(-\nabla_x \log p_t(x_t)\cdot(x_{t+\Delta t} - x_t) - \frac{\partial \log p_t(x_t)}{\partial t}\Delta t + O(\Delta t)\right). \end{aligned}$$

代数处理。 关键是对指数配方。先有

$$\begin{aligned} &-\frac{\|x_{t+\Delta t} - x_t - f(x_t,t)\Delta t\|_2^2}{2g^2(t)\Delta t} - \nabla_x \log p_t(x_t)\cdot(x_{t+\Delta t} - x_t) \\ &= -\frac{\|x_{t+\Delta t} - x_t - f(x_t,t)\Delta t\|_2^2 + 2g^2(t)\Delta t\nabla_x \log p_t(x_t)\cdot(x_{t+\Delta t} - x_t)}{2g^2(t)\Delta t}. \end{aligned}$$

令 $\delta := x_{t+\Delta t} - x_t$、$\mu := f(x_t,t)\Delta t$，则

$$\begin{aligned} &\|\delta - \mu\|_2^2 + 2g^2(t)\Delta t\nabla_x \log p_t(x_t)\cdot\delta \\ &= \|\delta\|_2^2 - 2\delta\cdot\mu + \|\mu\|_2^2 + 2g^2(t)\Delta t\nabla_x \log p_t(x_t)\cdot\delta \\ &= \|\delta\|_2^2 - 2\delta\cdot[\mu - g^2(t)\Delta t\nabla_x \log p_t(x_t)] + \|\mu\|_2^2 \\ &= \|\delta - [\mu - g^2(t)\Delta t\nabla_x \log p_t(x_t)]\|_2^2 - \|g^2(t)\Delta t\nabla_x \log p_t(x_t)\|_2^2. \end{aligned}$$

译注： 原文末行等号缺少 $2\mu\cdot[g^2(t)\Delta t\nabla_x \log p_t(x_t)]$。该项为 $O(\Delta t^2)$，经除以 $2g^2\Delta t$ 为指数的 $O(\Delta t)$ 项；原文后续为启发主导阶论证，但此处写成精确代数等式并不成立。保留原式，未暗中更正。

代回平方部分，

$$\begin{aligned} &\|\delta - [f(x_t,t)\Delta t - g^2(t)\Delta t\nabla_x \log p_t(x_t)]\|_2^2 \\ &= \|x_{t+\Delta t} - x_t - [f(x_t,t) - g^2(t)\nabla_x \log p_t(x_t)]\Delta t\|_2^2. \end{aligned}$$

因此原文得到

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) &= \frac{1}{(2\pi g^2(t)\Delta t)^{D/2}} \\ &\quad \times \exp\left(-\frac{\|x_{t+\Delta t} - x_t - [f(x_t,t) - g^2(t)\nabla_x \log p_t(x_t)]\Delta t\|_2^2}{2g^2(t)\Delta t}\right) \exp(O(\Delta t)) \\ &= \mathcal{N}(x_t; x_{t+\Delta t} - [f(x_t,t) - g^2(t)\nabla_x \log p_t(x_t)]\Delta t, g^2(t)\Delta t I)\,(1 + O(\Delta t)). \end{aligned}$$

配方产生的额外平方项为 $O(\Delta t^2)$，可吸收进误差；时间导数项乘步长为 $O(\Delta t)$，在连续极限消失。

取连续极限。 小步长、光滑假设下，近似有

$$\begin{aligned} f(x_t,t) &\approx f(x_{t+\Delta t}, t+\Delta t), & g(t) &\approx g(t+\Delta t), \\ \nabla_x \log p_t(x_t) &\approx \nabla_x \log p_{t+\Delta t}(x_{t+\Delta t}) = s(x_{t+\Delta t}, t+\Delta t). \end{aligned}$$

代入整理，逆核近似为

$$\begin{aligned} p(x_t \mid x_{t+\Delta t}) &\approx \frac{1}{(2\pi g^2(t)\Delta t)^{D/2}} \\ &\quad \times \exp\left(-\frac{\left\|x_t - \left(x_{t+\Delta t} - [f(x_{t+\Delta t}, t+\Delta t) - g^2(t+\Delta t)s(x_{t+\Delta t}, t+\Delta t)]\Delta t\right)\right\|_2^2}{2g^2(t+\Delta t)\Delta t}\right). \end{aligned}$$

即大致为正态分布，均值 $x_{t+\Delta t} - [f(x_{t+\Delta t}, t+\Delta t) - g^2(t+\Delta t)s(x_{t+\Delta t}, t+\Delta t)]\Delta t$，协方差 $g^2(t+\Delta t)\Delta t I$。令步长趋零，就“推导”出式 (4.1.6)。[21]

4.7 结束语

本章将变分和得分视角下的离散扩散统一为连续时间框架，说明 DDPM 和 NCSN 是不同漂移 / 波动系数 SDE 的离散化。框架基石是对应逆时间 SDE 的存在，正式定义逆转污染的生成过程。其漂移仅依赖一个未知量：每个时间边缘的得分 $\nabla_x \log p_t(x)$，进一步确立它在生成建模中的核心地位。

还引入了完全确定的 PF-ODE，其解沿与 SDE 相同的边缘密度演化，这由 Fokker–Planck 方程保证。深刻含义是：复杂生成任务从根本上等价于求解微分方程。训练学习定义向量场的得分，采样则数值积分。

确定性 PF-ODE 为第三个、也是最后一个扩散视角搭桥。学习由速度场支配的确定性变换，是近期重要生成模型家族的核心原理。下一章将

1. 从归一化流和神经 ODE 的起源探索流视角；
2. 说明它如何导向直接学习分布间输运速度场的现代流匹配框架。

最终会看到，从随机原理导出的 PF-ODE，也可从完全不同的流起源构造并推广，从而完成统一扩散图景。

[21] 译注：这里 f 和得分起初依赖被积分的 x_t，不能未经渐近控制就当作固定高斯参数；原文已经声明其启发性质。$O(\Delta t)$ 的核 / 指数误差也不能只因单步趋零就自动判定不影响生成元，严格极限需更细的矩或弱收敛控制。

第五章　流视角：从归一化流到流匹配

万物流变。
Heraclitus

概率论的基石变量替换公式（Tabak and Vanden-Eijnden, 2010; Turner, 2013）在现代生成建模中焕发新生。第 4 章说明，Fokker–Planck 方程描述扩散下概率密度的演化，同一边缘演化也可由 PF-ODE 确定性地实现。这自然启发直接从确定性概率输运研究生成建模。

密度的变量替换公式。　给定可逆变换 f，若 $z \sim p_{\text{prior}}$，则 $x = f(z)$ 的密度为

$$p(x) = p_{\text{prior}}(z) \left| \det \frac{\partial f^{-1}(x)}{\partial x} \right|, \qquad z = f^{-1}(x). \tag{5.0.1}$$

当变换易计算时，这个看似简单的公式允许双向输运样本和密度，构成第 5.1 节归一化流的基础。若将变换看成连续时间过程，又会如何?

本章从归一化流走向神经 ODE，再到流匹配。与第 4 章的关键联系是：得分 SDE 用学得得分构造 PF-ODE 速度，流匹配则直接学习速度。对同一扩散概率路径，这是同一确定性概率流的两个视角。图 5.1 给出依赖同一条件化原理的图景。流匹配将原理推广到常见高斯扩散之外。只要选定条件概率路径可高效抽样、条件速度可计算，就能在可抽样的更一般源、目标分布之间构造连续输运。为帮助理解，附录 B 将自足、直观地介绍变量替换原理的各种形式，从普通公式到连续性方程，再到含随机动力学的 Fokker–Planck 方程。

学完本章后，你将能够：

- 通过分布输运，把离散可逆变换的归一化流、连续时间速度场的神经 ODE 与流匹配联系起来；
- 认识与得分 SDE 的关键类比：同一扩散路径上，前者学习得分以确定 PF-ODE 速度，流匹配直接学习速度，二者都用可计算条件目标学习难计算边缘目标；
- 理解连续性方程如何在密度层面联系 ODE 速度场与分布演化；
- 理解流匹配如何将条件化策略推广到可抽样的一般源、目标之间，并通过可计算条件路径与速度保持无需模拟的训练；
- 区分指定概率路径 $\{p_t\}_{t\in[0,1]}$ 与实现它的具体速度场、耦合和粒子轨迹，理解不同流如何共享边缘；
- 理解两种互补的条件流构造：从条件概率路径导速度，或从条件流映射导轨迹速度。

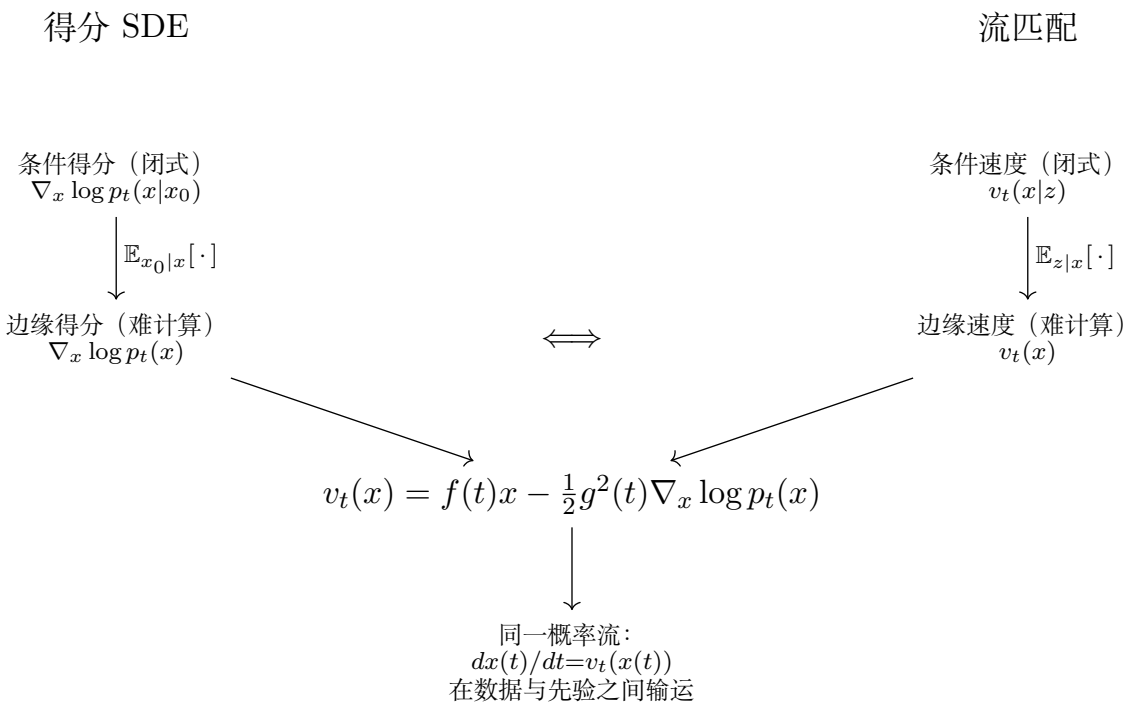


图 5.1: 得分 SDE 与流匹配。二者都用顶行的闭式条件量训练，对条件变量平均得到下方难计算的边缘量，也是模型恢复的量。两列只在学习何种量上不同。扩散路径上，得分通过中间公式确定速度，因此两路通向同一 ODE；流匹配直接学习速度，不要求任一端点高斯。来源：作者绘制；依原图重建。

阅读路线。 熟悉归一化流与神经 ODE 的读者可略读第 5.1 节，从第 5.2.1 节开始。初读关注得分 SDE 与流匹配的联系、连续性方程、条件到边缘速度构造；详细路径与可选理论性质留待之后。

5.1 流模型：归一化流与神经 ODE

本节介绍归一化流（NF）(Rezende and Mohamed, 2015) 与神经常微分方程（NODE）(Chen et al., 2018)。NF 用一系列可逆变换作用于简单基分布，实现灵活而可计算的密度估计。NODE 将其扩展到连续时间，变换由 ODE 支配，提供平滑、可扩展的延伸。

5.1.1 归一化流

NF 通过可逆映射 $f_\phi : \mathbb{R}^D \to \mathbb{R}^D$，将简单先验 $p_{\text{prior}}(z)$（例如标准高斯）变为复杂数据分布。$x = f_\phi(z)$，$z \sim p_{\text{prior}}$，二者同维。变量替换公式给出模型似然：[1]

$$\log p_\phi(x) = \log p_{\text{prior}}(z) + \log \left| \det \frac{\partial f_\phi^{-1}(x)}{\partial x} \right|. \tag{5.1.1}$$

[1]若进一步限制映射为凸势梯度 $f_\phi = \nabla\psi_\phi$、ψ_ϕ 凸，则式 (5.1.1) 化为原式 7.2.4 的 Monge–Ampère 关系，刻画二次代价下分布间最优变换；见第 7 章及 Huang et al. (2021)。

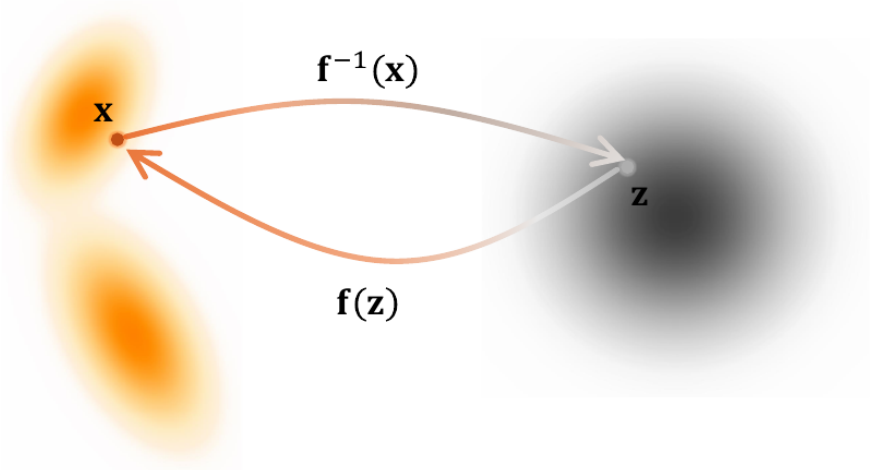


图 5.2: NF 可逆映射下样本移动。可逆函数 $f : z \mapsto x$ 将潜变量变为数据，逆映射 $f^{-1} : x \mapsto z$ 则按原文所称“重建数据”。它类似编码器—解码器结构，但编码器是光滑可逆映射，解码器恰为其逆。密度变化由式 (5.0.1) 计算。来源：作者绘制。译注：按所列定义，f^{-1} 实际返回潜变量 z，“重建数据”是原图注的措辞，勿据此颠倒映射方向。

训练目标。 通过最大化数据似然学习参数：

$$\mathcal{L}_{\mathrm{NF}}(\phi) = \mathbb{E}_{x\sim p_{\mathrm{data}}}[\log p_\phi(x)]. \tag{5.1.2}$$

一般 Jacobian 行列式计算代价为 $O(D^3)$。

构造可逆变换。 单个复杂可逆网络的行列式可能昂贵；简单线性变换高效，却缺乏表达力。为平衡，NF 使用 L 个 Jacobian 易计算的可训练可逆映射：

$$f_\phi = f_{L-1} \circ f_{L-2} \circ \cdots \circ f_0.$$

每个映射由网络参数化，为简洁省略对 ϕ 的显式依赖。样本按

$$x_{k+1} = f_k(x_k), \qquad k = 0, \ldots, L-1, \tag{5.1.3}$$

变换，$z = x_0 \sim p_{\mathrm{prior}}$、$x = x_L$ 为数据。密度为

$$\begin{aligned} p_\phi(x) &= p_{\mathrm{prior}}(x_0) \prod_{k=0}^{L-1} \left| \det \frac{\partial f_k}{\partial x_k} \right|^{-1}, \\ \log p_\phi(x) &= \log p_{\mathrm{prior}}(x_0) + \sum_{k=0}^{L-1} \log \left| \det \frac{\partial f_k}{\partial x_k} \right|^{-1}. \end{aligned} \tag{5.1.4}$$

可逆流的例子。 大量研究设计 Jacobian 易计算的单层构造。这里介绍平面流（Rezende and Mohamed, 2015）与残差流（Chen et al., 2019; Behrmann et al., 2019），后者启发下一小节。

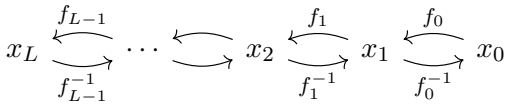


图 5.3: NF 由一叠可逆映射组成，$f_\phi = f_{L-1} \circ \cdots \circ f_0$，将潜变量样本 $x_0 \sim p_{\text{prior}}$ 映射为数据样本 $x_L \sim p_{\text{data}}$。来源：作者绘制；依原图节点与双向箭头重建。

平面流。 应用简单变换

$$f(z) = z + uh(w^\top z + b),$$

$u, w \in \mathbb{R}^D$、$b \in \mathbb{R}$，h 为激活函数。通过适当约束或重参数化保证可逆。行列式为

$$\left|\det \frac{\partial f(z)}{\partial z}\right| = |1 + h'(w^\top z + b)w^\top u|,$$

使变量替换高效。

残差流。 定义

$$f(z) = z + v(z), \tag{5.1.5}$$

v 为压缩映射，Lipschitz 常数小于一，由 Banach 不动点定理保证可逆。Jacobian 对数行列式化为迹展开：

$$\begin{aligned}
\log\left|\det \frac{\partial f(z)}{\partial z}\right| &= \log\left(\det \frac{\partial f(z)}{\partial z}\right) \\
&= \operatorname{Tr}\left(\log \frac{\partial f(z)}{\partial z}\right) = \operatorname{Tr}\left(\log\left(I + \frac{\partial v(z)}{\partial z}\right)\right) \\
&= \sum_{k=1}^{\infty} \frac{(-1)^{k+1}}{k} \operatorname{Tr}\left(\left(\frac{\partial v(z)}{\partial z}\right)^k\right),
\end{aligned} \tag{5.1.6}$$

可用迹估计（Hutchinson, 1989）高效求值。

采样与推断。 先抽 $x_0 \sim p_{\text{prior}}$，计算 $x = f_\phi(x_0)$。精确似然由式 (5.1.4) 得到。

5.1.2 神经 ODE

从离散 NF 到连续 NF。 离散 NF 通过 L 个可逆映射复合输运。为得到有意义的连续深度极限，将每层写为小残差更新：

$$x_{k+1} = x_k + \Delta t v_\phi(x_k, t_k), \qquad t_k = k\Delta t, \qquad \Delta t = T/L.$$

速度指定各点运动方向，步长控制单层大小。图 5.5 给几何含义：L 增加时，同一源到目标输运分成更多近恒等双射，轨迹分辨更细，参考网格变形更平滑。$L \to \infty$、$\Delta t \to 0$，层索引成为连续时间，得到 $dx(t)/dt = v_\phi(x(t), t)$，称为神经 ODE 或连续归一化流。

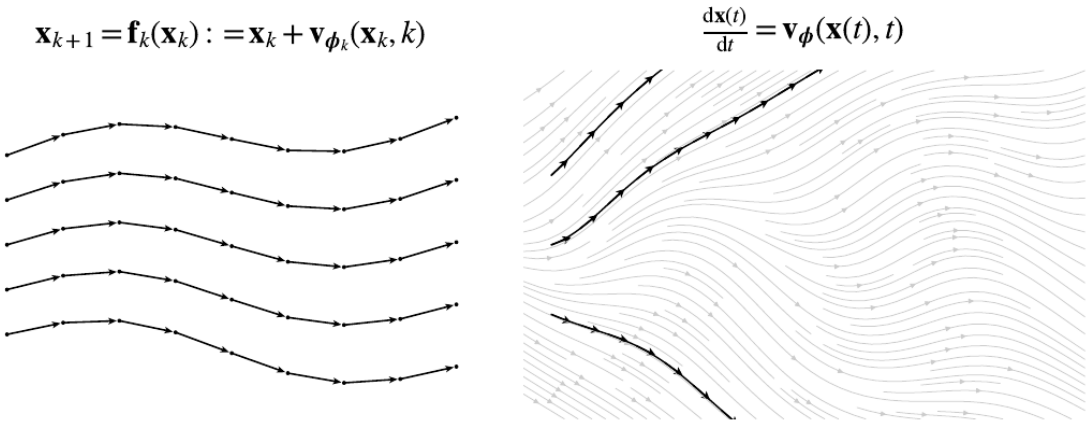


图 5.4: 离散与连续时间归一化流。左：有限可逆映射序列产生分步、互不交叉的轨迹（带箭头的点）。右：连续 NF（神经 ODE）沿 $dx(t)/dt = v_\phi(x(t), t)$ 的积分曲线演化，灰色向量场上画出带切向箭头的黑轨迹。来源：作者绘制。

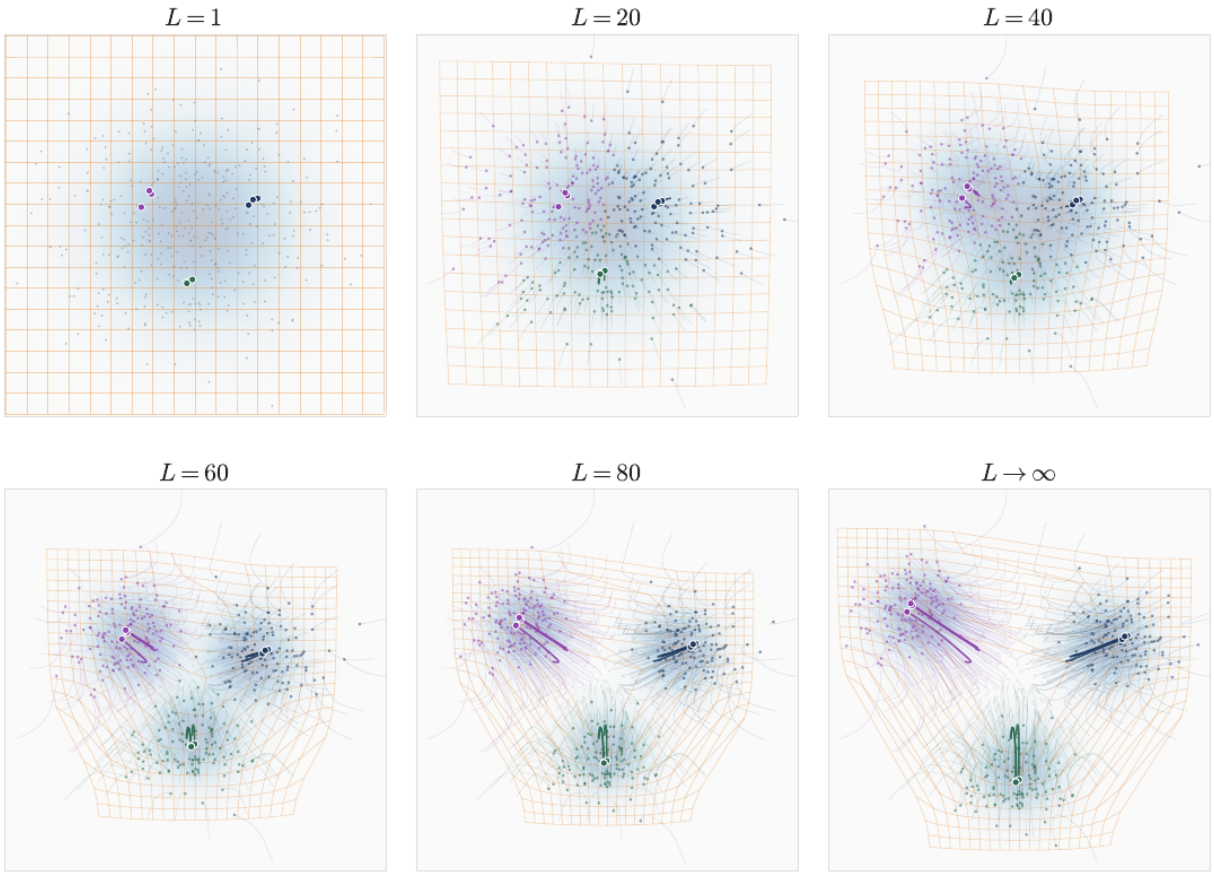


图 5.5: 从离散双射到连续输运流。各面板复合 L 个可逆层，从高斯源逐渐将彩色样本移到三模式目标；橙色参考网格显示周围空间变形。层少时每层变化大且离散，层多时更新更小，轨迹和网格更平滑。固定总时间 T、每层步长 T/L，无穷层极限趋于连续时变流。密度按后文连续性方程演化。来源：作者借助 AI 辅助编程绘制。

形式设定。 神经 ODE 通过

$$\frac{dx(t)}{dt} = v_\phi(x(t), t), \qquad t \in [0, T] \tag{5.1.7}$$

定义连续变换，$x(t) \in \mathbb{R}^D$ 是状态，有时简写 x_t；v_ϕ 是参数为 ϕ 的网络。

NODE 的目标。 从 $x(0) \sim p_{\text{prior}}$ 出发，ODE 连续演化，诱导边缘族 $p_\phi(x_t, t)$，类似 PF-ODE。[2]目标是学习沿连续轨迹输运点的神经速度，使 $t = T$ 的终端分布匹配数据。这在单一框架中统一离散 NF 与 NODE。

连续时间变量替换公式。 类似离散式，Chen et al. (2018) 推导瞬时变量替换：

$$\frac{d}{dt} \log p_\phi(x(t), t) = -\nabla_x \cdot v_\phi(x(t), t),$$

导数沿 ODE 轨迹取。从先验在 0 输运到 T，积分给出

$$\log p_\phi(x(T), T) = \log p_{\text{prior}}(x(0)) - \int_0^T \nabla_x \cdot v_\phi(x(t), t)\, dt. \tag{5.1.8}$$

数值积分可计算似然，从而进行最大似然训练。它与 Fokker–Planck 密切相关：是连续性方程沿轨迹的形式，而连续性方程是零扩散的确定性 Fokker–Planck 方程（附录 B）；也是离散变量替换的连续极限。

引理 5.1.1 (瞬时变量替换)**.** *令连续随机过程 $z(t)$ 具有时间依赖密度 $p(z(t), t)$，按 $dz(t)/dt = F(z(t), t)$ 演化。假设足够正则使流与密度良定义，则沿轨迹*

$$\frac{d}{dt} \log p(z(t), t) = -\nabla_z \cdot F(z(t), t). \tag{5.1.9}$$

证明. 由连续性方程与链式法则得到；附录 D.3 给详细的其他推导。 □

与离散公式的联系。 NODE 似然

$$\log p_\phi(x(T), T) = \log p_{\text{prior}}(x(0), 0) - \int_0^T \nabla_x \cdot v_\phi(x(t), t)\, dt$$

可看作离散式

$$\log p_\phi(x_L) = \log p_{\text{prior}}(x_0) - \sum_{k=0}^{L-1} \log \left| \det \frac{\partial f_k}{\partial x_k} \right|$$

的连续类似。积分对应求和，迹替代对数行列式，如式 (5.1.6)，引理证明还会探讨。

训练 NODE。 基于似然公式，学习速度，使从先验出发的轨迹终点满足 $p_\phi(\cdot, T) \approx p_{\text{data}}$。按最大似然框架，目标

$$\mathcal{L}_{\text{NODE}}(\phi) := \mathbb{E}_{x \sim p_{\text{data}}}[\log p_\phi(x, T)].$$

[2]本章翻转时间约定：$t = 0$ 是先验（源），$t = 1$ 是数据（目标）。先验交替写为 $p_\phi(x(0), 0)$、$p_{\text{prior}}(x(0), 0)$ 或 $p_{\text{prior}}(z)$。

精确对数似然计算。 对数据点 x，

$$\log p_\phi(x,T) = \log p_{\text{prior}}(z(0)) - \int_0^T \nabla_z \cdot v_\phi(z(t),t)\,dt, \tag{5.1.10}$$

其中 $z(t)$ 从 $z(T)=x$ 反向解 $dz(t)/dt = v_\phi(z(t),t)$ 到 0。标准先验密度可计算，使精确似然训练和评估成为可能。

基于梯度的优化。 最大化目标需通过 ODE 求解器反向传播。伴随灵敏度法（Pontryagin, 2018; Chen et al., 2018）通过辅助 ODE 以 $O(1)$ 内存复杂度计算梯度，但每步训练仍需数值积分，代价高昂。

NODE 的推断。 从 $x(0) \sim p_{\text{prior}}$ 出发，用训练模型正向数值积分

$$x(T) = x(0) + \int_0^T v_{\phi^\times}(x(t),t)\,dt,$$

终态近似数据样本。任意向量场满足 $\text{Tr}(\partial F/\partial z(t)) = \nabla_z \cdot F$，因此可用 Hutchinson 等随机迹估计，无需构造完整 Jacobian，在高维更实用。但随机样本估迹后，数值对数似然是随机估计，不是散度的精确求值。

图 5.5 展示许多小双射趋于连续流之后，一个实际问题是：

问题 5.1.1： 如何在训练时不反复解 ODE，仍学到速度场？

它自然导向通过无需模拟的回归目标直接学习速度的流匹配，提供扩散的流视角。

5.2 流匹配框架

得分 SDE（第 4 章）与 NODE（第 5.1 节）都把生成描述为连续输运。前者通过随机动力学及关联 PF-ODE，后者直接参数化确定性 ODE。在标准生成设定中，二者都旨在将简单高斯先验变为数据分布。

NODE 的实际局限是，似然训练需要反复求解 ODE。流匹配（FM）（Lipman et al., 2022; Lipman et al., 2024; Tong et al., 2024）通过回归直接训练速度预测网络，避免这一代价：生成需要 ODE 积分，训练循环内不需要，故称无需模拟。

更一般地，FM 不限于高斯到数据，而考虑易抽样的源分布 p_{src} 与目标分布 p_{tgt}。标准生成是 $p_{\text{src}} = p_{\text{prior}}$、$p_{\text{tgt}} = p_{\text{data}}$ 的特例，先验通常高斯。这里采用 FM 视角，[3]学习时间依赖速度 $v_t(x_t)$，使关联 ODE 沿指定概率路径输运，满足 $p_0 = p_{\text{src}}$、$p_1 = p_{\text{tgt}}$。源高斯时，称为高斯流匹配。因此 FM 既是生成建模的无需模拟训练方法，也是一般端点之间连续输运的框架。

5.2.1 从得分方法得到的启示

用稍有不同但等价的表述回顾得分 SDE，提取启发 FM 的洞见，说明扩散如何隐式学习概率流，并引出更直接形式。

[3]若干相关方法都用连续时间流在端点分布间输运，表述略有区别：Flow Matching（Lipman et al., 2022; Neklyudov et al., 2023）、Rectified Flow（Liu, 2022; Heitz et al., 2023）和随机插值（Albergo et al., 2023; Albergo and Vanden-Eijnden, 2023; Ma et al., 2024）。这里统一用 FM 术语。

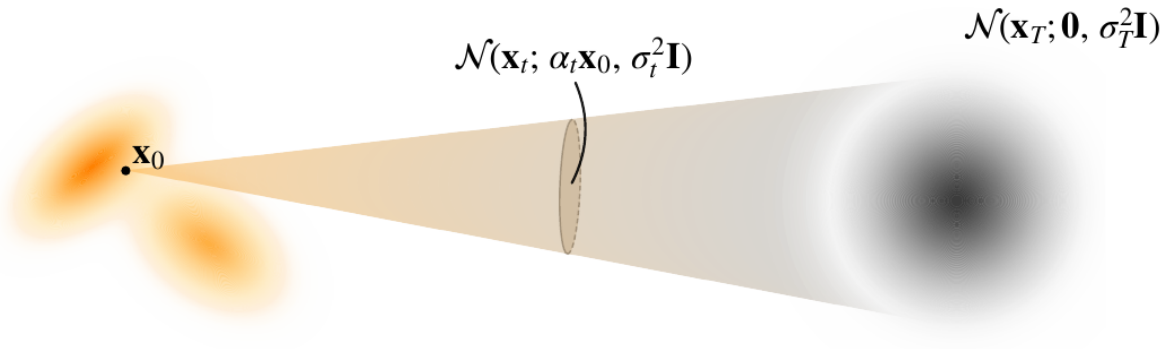


图 5.6: 条件转移分布。$p_t(x_t \mid x_0) = \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I)$ 定义从左侧数据样本 $x_0 \sim p_{\text{data}}$ 朝右侧高斯先验的条件概率路径。来源：作者绘制。

1. **定义条件路径与边缘密度**。扩散指定连续密度族，从 $t = 1$ 的简单先验（源）输运到 $t = 0$ 的数据（目标）：$p_1(x_1) = p_{\text{prior}}(x_1)$、$p_0(x_0) = p_{\text{data}}(x_0)$。路径通过正向条件分布隐式定义：

$$p_t(x_t \mid x_0) = \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I), \qquad x_0 \sim p_{\text{data}}, \tag{5.2.1}$$

   诱导边缘 $p_t(x_t) := \int p_t(x_t \mid x_0) p_{\text{data}}(x_0)\, dx_0$。条件高斯的递增方差驱动边缘朝高斯先验演化。

2. **速度场**。由 Fokker–Planck 方程导出的速度

$$v_t(x) := f(t)x - \tfrac{1}{2} g^2(t) \nabla_x \log p_t(x) \tag{5.2.2}$$

   控制边缘演化，定义确定性 PF-ODE：$dx(t)/dt = f(t)x(t) - \frac{1}{2} g^2(t) \nabla_x \log p_t(x(t))$。它从数据正向、或从先验反向输运，始终匹配 p_t，见下文“底层规则”。标量系数由相应正向 SDE，或等价的高斯核参数决定，见引理 4.5.1。

3. **通过条件化策略学习**。速度依赖未知边缘得分，因此以网络通过理想目标学习：

$$\mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{t \sim \mathcal{U}[0,1], x_t \sim p_t} [\| s_\phi(x_t, t) - \nabla_{x_t} \log p_t(x_t) \|^2].$$

   学得后，以 $s_{\phi^\times} \approx \nabla \log p_t$ 构造 PF-ODE 速度。边缘得分不可访问，而条件分布可计算，满足

$$\nabla_{x_t} \log p_t(x_t) = \mathbb{E}_{x_0 \sim p(\cdot \mid x_t)} [\nabla_{x_t} \log p_t(x_t \mid x_0)]. \tag{5.2.3}$$

   这启发 DSM 目标

$$\mathcal{L}_{\text{DSM}}(\phi) := \mathbb{E}_{t, x_0 \sim p_{\text{data}}, x_t \sim p_t(\cdot \mid x_0)} [\| s_\phi(x_t, t) - \nabla_{x_t} \log p_t(x_t \mid x_0) \|^2].$$

   定理 3.3.1 说明二者只差与参数无关常数，具有相同总体最小化解，即条件得分的后验平均，也就是真实边缘得分。其总体最优解显式写为

$$s^*(x_t, t) = \mathbb{E}_{x_0 \sim p(\cdot \mid x_t)} [\nabla_{x_t} \log p_t(x_t \mid x_0)] = \nabla_{x_t} \log p_t(x_t).$$

同一原理可直接表述于速度层面。定义

$$v_t(x_t \mid x_0) := f(t)x_t - \tfrac{1}{2}g^2(t)\nabla_{x_t}\log p_t(x_t \mid x_0),$$
$$v_t(x_t) = \mathbb{E}_{x_0\sim p(\cdot|x_t)}[v_t(x_t \mid x_0)].$$

因此得分扩散通过条件目标学习得分，再构造速度；FM 将同样的条件到边缘原理直接用于速度。

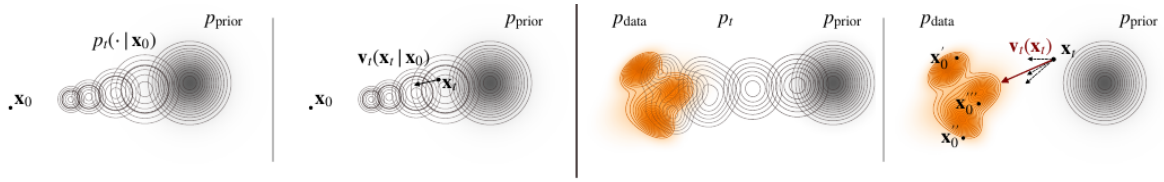


图 5.7: 扩散中条件与边缘视角（受 Lipman et al., 2024 启发）。四幅依次是：从固定 x_0 朝先验扩展的条件高斯路径；条件速度 $f(t)x_t - \frac{1}{2}g^2(t)\nabla_{x_t}\log p_t(x_t \mid x_0)$；将橙色数据输运到灰色先验的边缘密度；边缘速度，由含噪点朝多个合理起源的条件方向（虚线）平均得到红箭头。单边条件 $z = x_0$ 的 FM 同样适用这幅图，无需显式用得分写速度。来源：作者绘制。

底层规则：Fokker–Planck 方程。 边缘满足

$$\frac{\partial p_t(x)}{\partial t} + \nabla\cdot\left(\underbrace{\left(f(t)x - \tfrac{1}{2}g^2(t)\nabla_x\log p_t(x)\right)}_{v_t(x)}p_t(x)\right) = 0.$$

它保证 PF-ODE 密度匹配正向 SDE 边缘。回忆式 (4.2.2) 的流映射，逆向从 $x_1 \sim p_{\text{prior}}$ 出发，推前密度为

$$p_t^{\text{rev}}(x) = \int \delta(x - \Psi_{1\to t}(x_1))p_{\text{prior}}(x_1)\,dx_1. \tag{5.2.4}$$

Fokker–Planck 方程保证

$$p_t^{\text{rev}} = p_t, \tag{5.2.5}$$

特别 $p_0^{\text{rev}} = p_0 = p_{\text{data}}$。流映射双向，也可从数据正向求解，进行平行分析。

5.2.2 流匹配框架

上一小节说明，扩散通过学习满足边界条件、在分布间输运的速度场而成功；原文此处将其称作 “具体来说就是得分”。[4]高斯条件路径的设计隐式固定一个高斯先验端点，也使条件密度覆盖全空间，便于得分梯度计算。FM 据此扩展到任意源与目标，图 5.7 仍适用。

1. **定义条件路径与边缘密度**。任意 $\mathbb{R}^D$ 上源、目标分布，设

$$p_0(x) = p_{\text{src}}(x), \qquad p_1(x) = p_{\text{tgt}}(x). \tag{5.2.6}$$

[4]译注：得分与速度一般不是同一向量场，而由式 (5.2.2) 联系。保留原文概括，区分先学习得分与直接学习速度。

[5] 隐式定义端点间连续密度族，通过已知潜变量 $z \sim \pi(z)$ 及条件分布写成

$$p_t(x_t) = \int p_t(x_t \mid z)\pi(z)\, dz, \tag{5.2.7}$$

选择它们满足端点条件。一般边缘难计算，因为需对可能复杂的潜变量与条件分布积分。但条件化赋予超越高斯路径的灵活性。常见选择为：

- 双边条件：$z = (x_0, x_1) \sim p_{\text{src}}(x_0)p_{\text{tgt}}(x_1)$，$\pi$ 耦合源、目标，可定义任意分布间输运；
- 单边条件：$z = x_0$ 或 $z = x_1$，特别在源高斯时恢复类似扩散的设定。

所有情况下，条件路径应易抽样、条件速度应易计算。下文先从概率路径构造时，还用具有闭式表达的条件分布。具体构造见第 5.3.2 节和图 5.9。

2. **速度场**。概率路径规定分布如何演化，一般不指定每个样本如何移动，同一边缘序列可由不同速度实现。[6]FM 寻找 $v_t(x)$，使 ODE $dx(t)/dt = v_t(x(t))$ 在每个时间产生指定边缘。此时可从源正向到目标，也可从目标反向到源，后文给正式讨论。这一要求由连续性方程[7]表达：

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (v_t(x)p_t(x)) = 0. \tag{5.2.8}$$

合适正则条件下，任意满足它与初始条件的速度，都产生沿指定路径的边缘。求解 ODE 因而提供端点间逐样本输运，同时匹配中间分布。

连续性方程约束密度演化，一般不唯一确定速度。不同轨迹可产生相同边缘。例如在 $p_t > 0$ 区域，若 v_t 满足方程，则对充分正则且无散度的 $\widetilde{v}_t$，$v_t + \widetilde{v}_t/p_t$ 也满足。一般端点下，边缘及其速度均无闭式，因此转向下一步的可计算条件构造。第 5.3.1 节以特定仿射流映射下的高斯到高斯路径具体展示。

3. **通过条件化策略学习**。选定概率路径及对应边缘速度后，直接用网络 v_ϕ 学习，理想目标为

$$\mathcal{L}_{\text{FM}}(\phi) = \mathbb{E}_{t,x_t\sim p_t}[\|v_\phi(x_t, t) - v_t(x_t)\|^2].$$

称为 v 预测（速度预测），因为网络直接预测 ODE 漂移，区别于先学得分再构造速度。困难是边缘速度通常难计算。引入 $z \sim \pi$，构造易处理的条件路径与条件速度。若每个条件速度生成其条件路径，则边缘化得到有效边缘速度：

$$v_t(x_t) := \mathbb{E}_{z\sim p(\cdot|x_t)}[v_t(x_t \mid z)]. \tag{5.2.9}$$

这直接类似条件得分恒等式 (5.2.3)。于是得到条件流匹配（CFM）目标：

$$\mathcal{L}_{\text{CFM}}(\phi) := \mathbb{E}_{t,z\sim\pi(z),x_t\sim p_t(\cdot|z)}[\|v_\phi(x_t, t) - v_t(x_t \mid z)\|^2]. \tag{5.2.10}$$

[5]为与 FM 文献标准记号一致，相对前文翻转时间轴：0 对应源，1 对应目标。

[6]区别是分布演化与粒子层面的输运。加入额外结构后才确定具体速度：例如充分正则、可逆流映射通过 $v_t = \partial_t\Psi_{0\to t} \circ \Psi_{0\to t}^{-1}$ 确定 Euler 速度；指定正向扩散 SDE 后，其 PF-ODE 也选定 $f(t)x - \frac{1}{2}g^2(t)\nabla_x \log p_t(x)$。二者都提供边缘路径之外的粒子输运结构。

[7]Fokker–Planck 方程的确定性、无扩散对应物。

z 用于构造样本与目标，并不是网络的额外输入。两目标只差与 ϕ 无关的常数 $C \le 0$，$\mathcal{L}_{\mathrm{FM}} = \mathcal{L}_{\mathrm{CFM}} + C$，故总体最小化解相同：

$$v^*(x_t, t) = v_t(x_t). \tag{5.2.11}$$

单次实例以条件速度为目标，平均后恢复所需边缘速度。实现可计算、无需模拟的训练有两个实际条件：

(a) 无需求解 ODE 即可容易抽取 $x_t \sim p_t(\cdot \mid z)$；

(b) 条件速度有可用作回归目标的可计算表达。

第 5.3.2 节给具体构造。因此，正如 DSM 以条件得分学习边缘得分，FM 以条件速度学习边缘速度。

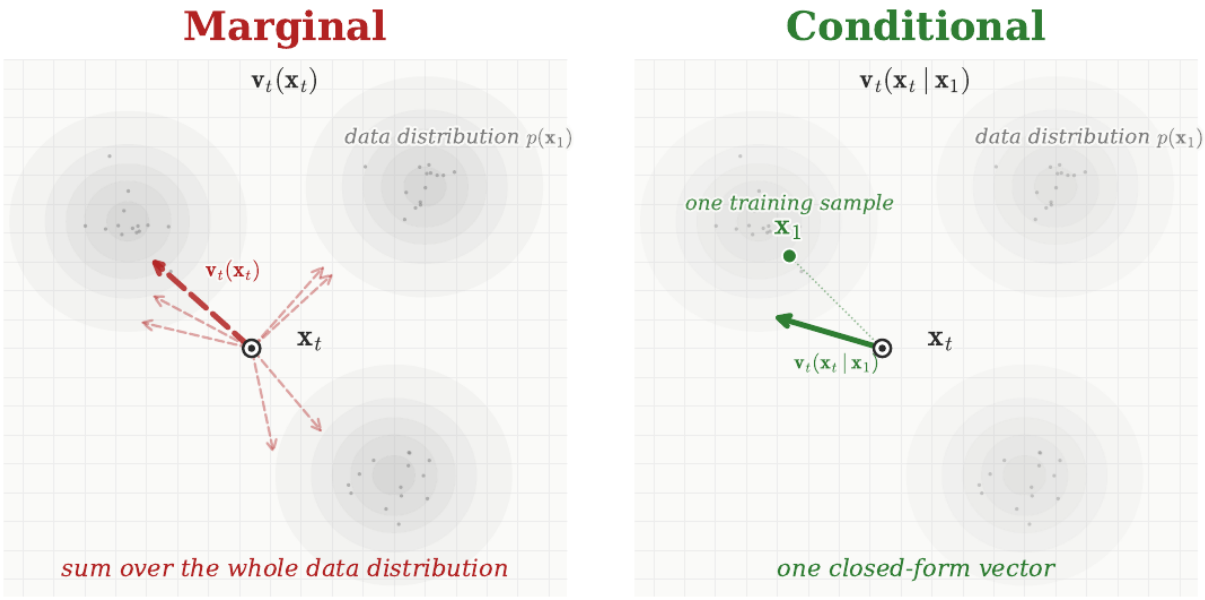


图 5.8: 流匹配的条件化技巧。$x_1 \sim p_{\mathrm{tgt}}$ 为目标样本。左：固定中间样本 x_t，边缘速度平均所有可能产生它的目标 x_1 的条件速度，按与观测相容程度加权，通常难以直接积分。右：训练时知道构造样本所用的 x_1，条件速度 $v_t(x_t \mid x_1) = b_t' x_1 + (a_t'/a_t)(x_t - b_t x_1)$ 有闭式，是简单回归向量（后文命题 5.3.1）。每例虽只条件于一个目标，但平均目标与直接边缘训练有相同最优速度，见定理 5.2.1。这与 DDPM 定理 2.2.1 和 DSM 定理 3.3.1 是同一条件化原理。图内 Marginal / Conditional 为“边缘 / 条件”，底部为“对全数据分布求和 / 一个闭式向量”。来源：作者借助 AI 辅助编程绘制。

定理 5.2.1 (FM 与 CFM 的等价性)**.** *$\mathcal{L}_{\mathrm{FM}}(\phi) = \mathcal{L}_{\mathrm{CFM}}(\phi) + C$，其中 C 与 ϕ 无关。二者最小化解对几乎处处 $x_t \sim p_t$ 满足 $v^*(x_t, t) = v_t(x_t)$，v_t 由式 (5.2.9) 定义。*

证明. 论证和最小化解推导与得分匹配命题 4.3.1 完全相同。 □

这是条件化技巧第三次给出可计算训练目标，见图 5.8；变分、得分和流方法都反映同一原理。

注。 取 $\pi = p_{\text{data}}$，由 Bayes 规则，$p(x_0 \mid x_t) = p_t(x_t \mid x_0)p_{\text{data}}(x_0)/p_t(x_t)$。得分模型也有类似分解：

$$\begin{aligned}\nabla_{x_t} \log p_t(x_t) &= \mathbb{E}_{x_0 \sim p(\cdot \mid x_t)}[\nabla_{x_t} \log p_t(x_t \mid x_0)] \\ &= \mathbb{E}_{x_0 \sim p_{\text{data}}}\left[\nabla_{x_t} \log p_t(x_t \mid x_0) \frac{p_t(x_t \mid x_0)}{p_t(x_t)}\right].\end{aligned}$$

这对应式 (5.2.9) 的边缘化。正如第 5.2.1 节需显式指定条件密度与条件速度，一般 CFM 也需这两个部分；我们尚未构造它们，第 5.3 节将给常见实例。

5.2.3 扩散模型、一般流匹配与 NODE 的比较

扩散与一般 FM。 FM 保留相同底层原理，表 5.1 总结其相似处。假设高斯调度满足引理 4.5.1 的扩散兼容条件，高斯 FM 本质上等价于相应扩散表述（第 6 章会详述），除非特别说明不作区分。

表 5.1: 扩散模型（或高斯 FM）与一般 FM。一般 FM 此处指独立抽取 $x_0 \sim p_{\text{src}}$、$x_1 \sim p_{\text{tgt}}$ 的双边条件设定。

方面	基于得分的扩散模型	一般 FM
源分布	高斯先验	任意
目标分布	数据分布	任意
潜分布 $\pi(z)$	p_{data}	见第 5.3.2 节
条件密度	$\mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I)$	见第 5.3.2 节
边缘密度	$\int p_t(x_t \mid x_0)p_{\text{data}}(x_0)\, dx_0$	$\int p_t(x_t \mid z)\pi(z)\, dz$
条件速度	$f(t)x - \frac{1}{2}g^2(t)\nabla \log p_t(x \mid x_0)$	见第 5.3.2 节
边缘速度	$f(t)x - \frac{1}{2}g^2(t)\nabla \log p_t(x)$	式 (5.2.9)
学习目标	$\mathcal{L}_{\text{SM}} = \mathcal{L}_{\text{DSM}} + C$	$\mathcal{L}_{\text{FM}} = \mathcal{L}_{\text{CFM}} + C$
底层规则	Fokker–Planck / 连续性方程	

与 NODE 的联系。 FM 可看成无需模拟的 NODE 替代。连续 NF 的最大似然训练需要昂贵 ODE 求解，FM 则直接用简单损失回归指定速度。关键洞见是：一旦固定连接端点的边缘路径，训练就不必精确模拟。

5.2.4 （可选）底层规则

连续性方程：质量守恒判据。 类似 PF-ODE 分析，我们给出流诱导密度与规定路径对齐的判据。考虑 $dx(t)/dt = v_t(x(t))$，它定义任意 $s, t \in [0,1]$ 的流映射，特别将 0 时刻 $x_0 \sim p_{\text{src}}$ 带到时刻 t。推前分布为

$$p_t^{\text{fwd}}(x) = \int \delta(x - \Psi_{0\to t}(x_0))p_{\text{src}}(x_0)\, dx_0 =: \Psi_{0\to t}\sharp p_{\text{src}}. \tag{5.2.12}$$

也可由 $\Psi_{1\to 0}$ 将目标反向送回源。给定路径并构造速度，便产生一个问题：

问题 5.2.1： 什么条件下，流诱导密度在所有 t 精确匹配规定的 p_t？

对齐后，可灵活求解 ODE 在端点间输运。连续性方程描述演化密度的质量守恒，为此提供原则性判据。

定理 5.2.2 (质量守恒判据)**.** *流诱导密度在所有 $t \in [0,1]$ 满足 $p_t^{\mathrm{fwd}} = p_t$，当且仅当 (p_t, v_t) 对所有 t, x 满足*

$$\partial_t p_t(x) + \nabla_x \cdot (p_t(x) v_t(x)) = 0.$$

证明. 概念推导见附录 D.3.2 节，更严格处理见 Villani et al. (2008) 的 "Mass Conservation Formula"。 □

译注： 此判据沿本段共同初始条件 $p_0 = p_{\mathrm{src}}$，并需保证连续性方程或流的适当唯一性与正则性；不是脱离初值与解概念的无条件等价。

从条件到边缘路径。 定义条件路径与对应速度，构造边缘速度

$$v_t(x) = \int v_t(x \mid z) \frac{p_t(x \mid z)\pi(z)}{p_t(x)}\, dz.$$

还需验证其流产生规定边缘。幸而只需在条件层面验证：每个条件速度诱导对应条件密度，就保证边缘速度也诱导正确边缘。

命题 5.2.3 (边缘速度生成给定边缘密度)**.** *若 $v_t(\cdot \mid z)$ 从 $p_0(\cdot \mid z)$ 出发诱导匹配 $p_t(\cdot \mid z)$ 的路径，则式 (5.2.9) 的边缘速度从 p_0 出发，诱导匹配 p_t 的路径。*

证明. 验证连续性方程即可。反向组织论证，以说明边缘速度为何这样定义。各条件对满足

$$\frac{d}{dt} p_t(x \mid z) = -\nabla_x \cdot (v_t(x \mid z) p_t(x \mid z)), \tag{5.2.13}$$

希望找到满足

$$\frac{d}{dt} p_t(x) = -\nabla_x \cdot (v_t(x) p_t(x)) \tag{5.2.14}$$

的边缘速度。由边缘定义，

$$\begin{aligned}
\frac{d}{dt} p_t(x) &= \frac{d}{dt} \int p_t(x_t \mid z)\pi(z)\, dz \\
&= -\int \nabla_x \cdot (v_t(x \mid z) p_t(x \mid z))\pi(z)\, dz \\
&= -\nabla_x \cdot \left(\int v_t(x \mid z) p_t(x \mid z)\pi(z)\, dz \right).
\end{aligned}$$

比较式 (5.2.14)，除一个无散度项外，$v_t(x)p_t(x) = \int v_t(x \mid z) p_t(x \mid z)\pi(z)\, dz$，因此可定义

$$v_t(x) := \int v_t(x \mid z) \frac{p_t(x \mid z)}{p_t(x)} \pi(z)\, dz,$$

恰好是条件平均。证明本质上逆向走上述步骤。 □

这将潜在难计算的边缘速度构造，化为按设计更简单的条件场定义。

5.3 构造分布间的概率路径与速度

流匹配的本质是将源逐渐变为目标。需要两个要素：概率路径给出各时刻分布快照，速度场描述粒子如何移动。二者通过连续性方程联系，保证粒子动力学与分布演化相容，学习因而化为寻找忠实驱动过程的速度。但一般复杂分布的真实边缘速度未知，目标无法直接访问。

CFM 的核心是构造人为但可计算的过程。引入条件变量 z，设计简单的条件速度和 / 或条件路径。它们已知闭式，可作为模型回归的替代目标；只要能高效从条件路径抽样，并有闭式条件速度，就得到有效 CFM 损失。如何设计良好条件过程？可从完全可解的高斯到高斯桥获得启发：各时间取高斯路径，或规定仿射速度场，均可解析处理。

由此向一般端点推广，有两种互补构造（另见附录 B.1.2），对应经典 Euler 与 Lagrange 输运描述：

- **先指定条件概率路径（Euler 视角）：** 从 $p_t(\cdot \mid z)$ 开始，寻找满足连续性方程的条件速度。密度路径一般不唯一确定速度，还需选定某个相容速度。
- **先指定条件流（Lagrange 视角）：** 直接用流映射规定粒子运动，推前得到密度；若流映射可逆，则 $v_t = \partial_t \Psi_{0\to t} \circ \Psi_{0\to t}^{-1}$。

第 5.3.2 节介绍第一种，与扩散构造紧密类似；第 5.3.3 节介绍第二种。二者为定义条件密度与速度提供实用框架，支持无需模拟训练及任意端点间流构造。

5.3.1 关键特例：高斯到高斯桥的边缘与速度

源、目标高斯时，可解析计算边缘与速度，为一般条件构造提供模板。考虑

$$p_t(x_t) = \mathcal{N}(x_t; \mu(t), \sigma^2(t) I), \tag{5.3.1}$$

均值与方差随时间变化，$\sigma^2(t) > 0$。端点是 $p_{\text{src}} = p_0 = \mathcal{N}(x; \mu(0), \sigma^2(0) I)$ 和 $p_{\text{tgt}} = p_1 = \mathcal{N}(x; \mu(1), \sigma^2(1) I)$。同一路径有许多速度实现，一个特别简单的流映射为[8]

$$\Psi_{0\to t}(x) := \mu(t) + \sigma(t) \frac{x - \mu(0)}{\sigma(0)}. \tag{5.3.2}$$

对于该指定流映射，诱导它的速度唯一且可解析确定（Lipman et al., 2022）。

命题 5.3.1 (高斯密度路径的闭式速度)**.** *对式 (5.3.1) 的路径，实现指定流映射 (5.3.2) 的速度唯一，为*

$$v_t(x) = \frac{\sigma'(t)}{\sigma(t)}(x - \mu(t)) + \mu'(t).$$

证明. 初始条件 y 的 ODE 满足 $d\Psi_{0\to t}(y)/dt = v_t(\Psi_{0\to t}(y))$。因 $\sigma(t) > 0$，映射可逆，令 $x = \Psi_{0\to t}(y)$、$y = \Psi_{0\to t}^{-1}(x) = \Psi_{t\to 0}(x)$，得到 $v_t(x) = \Psi'_{0\to t}(\Psi_{0\to t}^{-1}(x))$。求导

$$\Psi'_{0\to t}(x) = \mu'(t) + \sigma'(t) \frac{x - \mu(0)}{\sigma(0)},$$

$$y = \mu(0) + \sigma(0) \frac{x - \mu(t)}{\sigma(t)}.$$

将逆映射代入导数，即得所述速度。 □

[8] Lipman et al. (2022) 取 $\Psi_{0\to t}(x) = \mu(t) + \sigma(t)x$，需对均值、尺度施加端点约束；这里用等价归一化形式避免此类约束。

固定流映射时速度由 $\partial_t \Psi \circ \Psi^{-1}$ 唯一确定，(p_t, v_t) 自动满足连续性方程。相反，只给密度路径而不固定映射，速度非唯一。这精确区分两种视角。闭式表征也可在给定潜变量 z 时使用，下面扩展为一般边缘设定下的条件高斯路径与速度。

5.3.2 先指定条件概率路径的构造

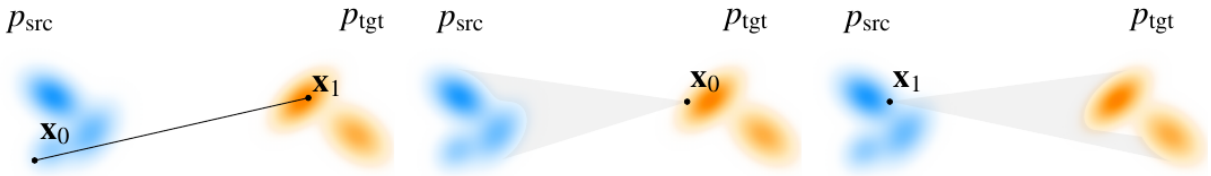


图 5.9: 两种常见条件概率路径。原图注列为：(i) 一般端点的双边条件，给定 $x_0 \sim p_{\text{tgt}}$、$x_1 \sim p_{\text{src}}$；(ii) 单边条件，给定上述任一端点。来源：作者绘制。译注：原图注的源 / 目标下标与图内及紧随正文的 $x_0 \sim p_{\text{src}}$、$x_1 \sim p_{\text{tgt}}$ 相反；这里保留原图和原注，并按正文约定开展推导。

先构造条件密度，再通过命题 5.3.1 导出速度。条件变量可取双边 $z = (x_0, x_1)$，或单边 $z = x_0$、x_1。都必须匹配边界：

$$p_{\text{src}}(x_0) = \int p_0(x_0 \mid z)\pi(z)\, dz, \qquad p_{\text{tgt}}(x_1) = \int p_1(x_1 \mid z)\pi(z)\, dz.$$

具体构造后容易验证，故不特别强调验证步骤。

1. **双边 $z = (x_0, x_1)$：“光束状”路径。**

   π 的选择。 一般端点上独立抽取 $x_0 \sim p_{\text{src}}$、$x_1 \sim p_{\text{tgt}}$，即 $\pi(z) = p_{\text{src}}(x_0)p_{\text{tgt}}(x_1)$。

   条件路径的选择。 以固定小方差 $\sigma^2 > 0$ 定义线性插值：[9]

   $$p_t(x_t \mid z = (x_0, x_1)) = \mathcal{N}(x_t; a_t x_0 + b_t x_1, \sigma^2 I).$$

   时间函数满足 $a_0 = 1, b_0 = 0, a_1 = 0, b_1 = 1$。Lipman et al. (2022)、Liu (2022) 建议 $a_t = 1 - t$、$b_t = t$。确定性 $\sigma = 0$ 时，$p_t(x_t \mid z) = \delta(x_t - [a_t x_0 + b_t x_1])$，从一个端点确定性插值到另一个。

   导出的条件速度。 由高斯速度命题，$v_t(x \mid z) = a_t' x_0 + b_t' x_1$。

[9] 也可加入固定条件方差 $\sigma^2 I$。因方差不随时间变化，速度仍为 $a_t' x_0 + b_t' x_1$，但端点边缘变为源、目标的高斯平滑，$\sigma \to 0$ 时才接近所需端点。译注：原文正文已取固定正方差，脚注又称“也可加入”；保留其表述，精确端点应区分下面的零方差极限。

CFM 损失。 $\sigma = 0$ 时 $x_t = a_t x_0 + b_t x_1$，

$$\mathcal{L}_{\mathrm{CFM}} = \mathbb{E}_{t,x_0\sim p_{\mathrm{src}},x_1\sim p_{\mathrm{tgt}}}[\|v_\phi(x_t,t) - (a_t' x_0 + b_t' x_1)\|^2],$$
$$v^*(x_t,t) = \mathbb{E}[x_t' \mid x_t] = \mathbb{E}[a_t' x_0 + b_t' x_1 \mid x_t].$$

这里期望对可能产生观测插值的端点对后验 $p(x_0, x_1 \mid x_t)$ 取。

2. **单边 $z = x_0$ 或 x_1："聚光灯状" 路径。**在标准生成设定 $p_{\mathrm{src}} = \mathcal{N}(0, I)$、$p_{\mathrm{tgt}} = p_{\mathrm{data}}$ 展示构造。高斯源不是额外假设，而是下面条件路径的直接结果；一般任意端点见第 5.3.3 节。

π 的选择。 取 $z = x_1$、$\pi = p_{\mathrm{data}}(x_1)$；$z = x_0 \sim p_{\mathrm{prior}}$ 类似。

条件路径。 固定 x_1，定义

$$p_t(x_t \mid z = x_1) = \mathcal{N}(x_t; b_t x_1, a_t^2 I),$$

边界系数仍取上述值（通常按极限理解）。因此 $p_0(\cdot \mid x_1) = \mathcal{N}(\cdot; 0, I)$、$p_1(\cdot \mid x_1) = \delta(\cdot - x_1)$；边缘化后，起点高斯且与数据无关，终点为数据。

导出的条件速度。 $t \in (0,1)$、$a_t > 0$ 时，

$$v_t(x \mid x_1) = b_t' x_1 + \frac{a_t'}{a_t}(x - b_t x_1).$$

单边 CFM 目标。 取 $t \sim \mathcal{U}(0,1)$ 或任意固定采样分布，$x_1 \sim p_{\mathrm{data}}$，

$$\mathcal{L}_{\mathrm{CFM}} = \mathbb{E}_{t,x_1}\mathbb{E}_{x_t\sim p_t(\cdot\mid x_1)}\left[\left\| v_\phi(x_t,t) - \left[b_t' x_1 + \frac{a_t'}{a_t}(x_t - b_t x_1)\right]\right\|_2^2\right]. \tag{5.3.3}$$

由 MSE 最优性，唯一最小化解是边缘速度；原式在此排为

$$v^*(x,t) = \mathbb{E}[v_t(x \mid x_1) \mid dle \mid x_t = x] = \mathbb{E}[a_t' x_0 + b_t' x_1 \mid dle \mid x_t = x].$$

译注：冻结 PDF 印页 162 确实在条件分隔处出现字母 `dle`；保留原误排。意图可由下一段正确的条件期望式确认，不将误排当作新算子。

与双边目标等价。 成对样本满足 $x_t = a_t x_0 + b_t x_1$，所以

$$v_t(x_t \mid x_1) = b_t' x_1 + \frac{a_t'}{a_t}(x_t - b_t x_1) = a_t' x_0 + b_t' x_1.$$

单边损失回归到给定中间样本的双边目标条件期望，$v^*(x,t) = \mathbb{E}[a_t' x_0 + b_t' x_1 \mid x_t = x]$；因此单、双边 CFM 有同一最小化解。

表 5.2: 写为 $x_t = a_t x_0 + b_t x_1$ 的各类插值，$x_0 \sim p_{\text{src}} = p_{\text{prior}}$、$x_1 \sim p_{\text{tgt}} = p_{\text{data}}$。FM / RF 与三角函数栏用 0 源、1 目标；VE / VP 保留 0 数据、1 先验，$a_t := \sigma_t, b_t := \alpha_t$。有限 VE 终点的真实边缘为数据与高斯卷积，高斯先验是终端噪声远大于数据尺度时的近似。

	VE	VP	FM / RF	三角（Albergo et al., 2023）
a_t（先验系数）	a_t	$\sqrt{1-b_t^2}$	$1-t$	$\cos(\pi t/2)$
b_t（数据系数）	1	b_t	t	$\sin(\pi t/2)$
a_0	0	0	1	1
b_0	1	1	0	0
a_1	a_1	1	0	0
b_1	1	0	1	1
p_{prior}	$p_{\text{data}} * \mathcal{N}(0, a_1^2 I) \approx \mathcal{N}(0, a_1^2 I)$	$\mathcal{N}(0, I)$	$\mathcal{N}(0, I)$	$\mathcal{N}(0, I)$

高斯 FM 与扩散模型。 主文采用 FM 时间方向，0 为源 / 先验、1 为目标 / 数据；扩散通常反向。为比较，表 5.2 的 VE、VP 栏保留常见扩散方向，0 数据、1 先验。源若为标准高斯，给定 $x_1 \sim p_{\text{data}}$ 的条件路径自然高斯，而目标本身无需高斯，称为高斯 FM。扩散概率路径是重要子类，但一般高斯调度未必对应有效正向扩散 SDE，仍需引理 4.5.1 的兼容条件。

取 $a_t = 1 - t, b_t = t$，等价于按 $a_t := \sigma_t, b_t := \alpha_t$ 重新命名后 $\alpha_t = t, \sigma_t = 1 - t$，恢复熟悉的 FM / RF 调度（Lipman et al., 2022; Liu, 2022）。高斯 FM 下，光束状和聚光灯状条件路径都导向类似标准扩散的目标。第 6 章将说明，线性调度的高斯 FM 可等价解释为预测速度的扩散模型；二者可相互转换。其实际吸引力在于简单的损失 $\mathbb{E}_{t,x_t}[\|v_\phi(x_t, t) - (x_1 - x_0)\|_2^2]$，并已在大规模应用中展示有竞争力的表现（Esser et al., 2024）。

5.3.3 先指定条件流的构造

现在处理任意源（0 时刻）与目标（1 时刻），直接在轨迹空间设计条件流，给出可用于回归的闭式速度。

动机。 不先指定密度路径，而直接指定移动样本的条件流映射。有两个实际优点：沿轨迹时间求导立即得到训练目标；对具有几何结构的空间，如 Riemann 流形、Lie 群或受约束子流形，直接由测地线、指数映射或预度量构造流映射往往自然（Lipman et al., 2024），可得到解析且无需模拟的训练速度。

条件仿射流。 固定 $z \sim \pi$，例如单边训练 $z = x_1 \sim p_{\text{tgt}}$，通过

$$\Psi_{0\to t}(x_0; z) := \mu_t(z) + A_t(z) x_0, \qquad t \in [0, 1]$$

推前 $x_0 \sim p_{\text{src}}$。$\mu_t(z) \in \mathbb{R}^D$，$A_t(z) \in \mathbb{R}^{D\times D}$ 在开区间可逆。边界 $A_0 = I, \mu_0 = 0$ 恢复源，$t \to 1$ 按极限理解，终端可能把质量集中到低维集合或一点。[10]

[10] 允许 $A_1(z)$ 奇异，例如为零，与开区间可逆相容，使路径在终点收缩至规定端点。

诱导的条件路径。 定义

$$p_t(\cdot \mid z) = (\Psi_{0\to t}(\cdot; z))\sharp p_{\text{src}}, \qquad p_t(\cdot) = \int p_t(\cdot \mid z)\pi(z)\, dz.$$

CFM 实际只需知道如何采样：先抽 z，再抽 $x_0 \sim p_{\text{src}}$，置 $x_t = \mu_t(z) + A_t(z)x_0$。由于映射对 x_0 仿射且可逆，条件路径高斯当且仅当源高斯；任意非高斯源一般给非高斯条件路径。

导出条件速度。 对条件流求时间导数。初始 y 的条件 ODE 为

$$\frac{d}{dt}\Psi_{0\to t}(y; z) = v_t(\Psi_{0\to t}(y; z) \mid z).$$

开区间可逆，因此当前状态 x 对应初始 $y = \Psi_{0\to t}^{-1}(x; z) = \Psi_{t\to 0}(x; z)$，Euler 速度为

$$v_t(x \mid z) := \frac{\partial}{\partial t}\Psi_{0\to t}(y; z)\Big|_{y=\Psi_{0\to t}^{-1}(x;z)}.$$

即固定初始点先求导，再代入在当前时刻到达 x 的那个初始点。由于 $x_0 = A_t(z)^{-1}(x - \mu_t(z))$，有

$$v_t(x \mid z) = \mu_t'(z) + A_t'(z)A_t(z)^{-1}(x - \mu_t(z)).$$

单边条件。 取 $\mu_t(z) = b_t z$、$A_t(z) = a_t I$，系数满足上述边界，开区间 $a_t > 0$，则

$$x_t = a_t x_0 + b_t x_1, \qquad v_t(x \mid x_1) = b_t' x_1 + \frac{a_t'}{a_t}(x - b_t x_1).$$

在成对样本上简化为通常 CFM 目标 $v_t(x_t \mid x_1) = a_t' x_0 + b_t' x_1$。

双边条件。 相同模板取 $\mu_t(x_0, x_1) = b_t x_1$、$A_t(x_0, x_1) = a_t I$，给出确定性条件路径

$$x_t = a_t x_0 + b_t x_1, \qquad p_t(\cdot \mid x_0, x_1) = \delta(\cdot - (a_t x_0 + b_t x_1)),$$
$$v_t(x_t \mid x_0, x_1) = a_t' x_0 + b_t' x_1,$$

即标准双边 CFM 目标。[11]

无条件高斯路径特例。 若 μ_t 与 z 无关，记作 $\mu(t)$，且 $A_t = \sigma(t)I/\sigma(0)$，则原文给出

$$\Psi_{0\to t}(x_0) = \mu(t) + \sigma(t)\frac{x_0 - \mu(0)}{\sigma(0)}, \qquad v_t(x) = \mu'(t) + \frac{\sigma'(t)}{\sigma(t)}(x - \mu(t)),$$

恢复高斯路径与闭式速度。[12]

[11]译注：本段双边条件已固定同一个 x_0，不再对一个额外独立的源随机点推前；需与上一段单边条件下仍随机抽取 x_0 区分。

[12]译注：一般仿射模板若直接令平移项为 $\mu(t)$，会缺少中心化偏移。要与所列归一化公式及 $\Psi_{0\to 0} = \mathrm{Id}$ 一致，平移项应按 $\mu(t) - [\sigma(t)/\sigma(0)]\mu(0)$ 理解；或限制 $\mu(0) = 0$。原文公式保留，明确模板代入的条件。

5.3.4 先指定概率路径与先指定流的比较

两种构造对应互补的 Euler 与 Lagrange 描述。前者从条件密度开始，通过连续性方程选择相容速度；密度本身一般不唯一确定速度，可能需要额外输运结构。后者从条件流映射直接描述粒子轨迹，密度由推前得到，可逆时速度唯一恢复为 $\partial_t \Psi \circ \Psi^{-1}$。

它们从不同起点描述同类输运对象，但单独指定路径未必选出与另行指定映射相同的速度。表 5.3 总结差异：条件路径具有闭式速度时，先指定路径自然；有强轨迹结构先验时，先指定流自然。

表 5.3: 先指定条件概率路径与先指定条件流的比较

维度	先指定条件概率路径	先指定条件流
给定对象	条件密度路径 $p_t(\cdot \mid z)$。	每个固定 z 的条件流映射 $\Psi_{0\to t}(\cdot \mid z)$，即轨迹。
得到速度	对每个 z，寻找满足 $\partial_t p_t + \nabla \cdot (p_t v_t) = 0$ 的速度。若 $\nabla \cdot (p_t w_t) = 0$，$v_t + w_t$ 也给同一路径，故不唯一。	沿路径 $v_t(\Psi_{0\to t}(\cdot \mid z) \mid z) = d\Psi_{0\to t}(\cdot \mid z)/dt$；可逆时，固定初始点求导，再代入 $y = \Psi_{0\to t}^{-1}(x \mid z)$。
闭式速度	条件路径为高斯 / 指数族时方便，否则求速度并不简单。	映射有仿射 / 低秩结构时方便，避免密度求值。
唯一性	对每个 z，除非施加势流或最小动能等选择规则，速度欠定。	给定映射，推前密度与粒子轨迹已确定；可逆时 Euler 速度唯一，否则未必存在唯一全局 Euler 场。
可实现性	必须在预期支集上验证所构造速度满足连续性方程。	由构造保证，$p_t(\cdot \mid z) = (\Psi_{0\to t}(\cdot \mid z))\sharp p_0(\cdot \mid z)$。
匹配端点	混合条件分布，$p_{\text{src}} = \int p_0(\cdot \mid z)\pi(z)dz$，目标类似。与 z 无关系数的高斯仿射条件路径可将源强制为高斯；一般固定、可能非高斯的源下，条件路径选择不一般将源限定为此特定类型。	设 $\Psi_{0\to 0} = \mathrm{Id}$，选择终端边界命中任意目标。
适用场景	类扩散构造，条件高斯给解析目标。	映射提供强结构先验，边界易控，可容纳奇异 / 低维端点，适合基于映射的正则化与输运代价。

5.3.5 条件路径笔直不意味着边缘流笔直

典范仿射插值 $x_t = (1-t)x_0 + tx_1$ 有吸引人的几何性质：固定端点对时，它是常速度 $x_1 - x_0$ 的直线，FM 与 RF 广泛使用这一条件直线性。

但必须区分条件插值路径与生成时的边缘 ODE 轨迹。耦合 $\pi(x_0, x_1)$ 下，总体最优边缘速度是 $v^\star(x,t) = \mathbb{E}[x_1 - x_0 \mid x_t = x]$。端点对后验一般随 (x,t) 改变，所以即使训练用每条条件路径都笔直，边缘轨迹沿途速度也未必不变。单选典范仿射调度，不蕴含学得 ODE 精确笔直或一次 Euler 步精确。RF 的整流 / Reflow 改变端点耦合，使诱导因果流逐渐接近直流（Liu, Gong, et al., 2022）。下面给明确反例。

例：简单一维反例。 取独立 $x_0 \sim \mathcal{N}(0, \sigma_0^2)$、$x_1 \sim \mathcal{N}(0, \sigma_1^2)$，按典范仿射插值。每条条件路径是时间的直线。因为 $(x_1 - x_0, x_t)$ 联合高斯，条件期望线性，

$$
\begin{aligned}
v^*(x,t) &= \mathbb{E}[x_1 - x_0 \mid x_t = x] = \frac{\mathrm{Cov}(x_1 - x_0, x_t)}{\mathrm{Var}(x_t)} x, \\
V(t) &:= \mathrm{Var}(x_t) = (1-t)^2\sigma_0^2 + t^2\sigma_1^2, \\
\mathrm{Cov}(x_1 - x_0, x_t) &= t\sigma_1^2 - (1-t)\sigma_0^2 = \tfrac{1}{2}V'(t), \\
v^*(x,t) &= \frac{V'(t)}{2V(t)} x.
\end{aligned}
$$

因此边缘 ODE $dz_t/dt = v^*(z_t, t)$ 的精确解为

$$
z_t = z_0 \sqrt{\frac{V(t)}{V(0)}} = z_0 \sqrt{(1-t)^2 + \frac{\sigma_1^2}{\sigma_0^2} t^2}.
$$

时间上的直线插值要求 $z_t = (1-t)z_0 + tz_1$，但上述平方根系数对任何正 σ_0, σ_1 都非 t 的仿射函数，因此轨迹一般不是时间线性插值。图 5.10 用 $\sigma_0 = 2, \sigma_1 = 3$ 展示。若二者相等，终点 $z_1 = z_0$，直线插值会是常路径，但实际 $z_{1/2} = z_0/\sqrt{2} \neq z_0$。所以即使所有条件路径笔直，诱导的边缘 ODE 轨迹也未必如此。

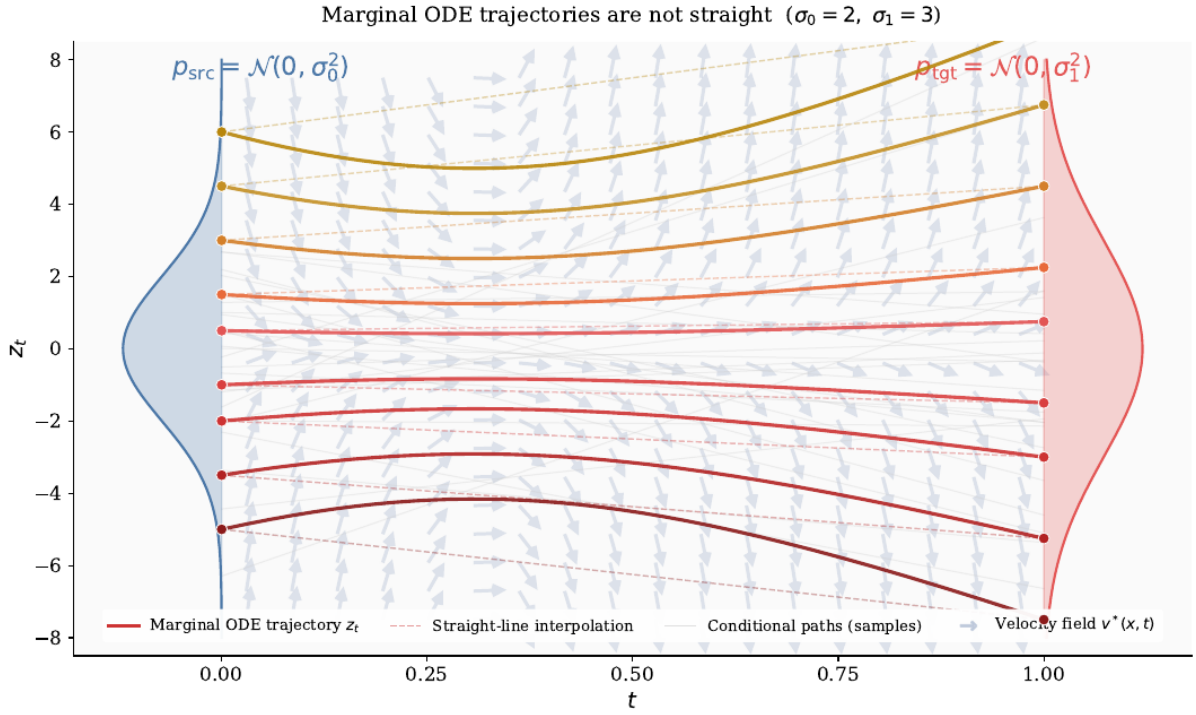


图 5.10: 典范仿射插值的边缘 ODE 轨迹不笔直。独立高斯端点尺度为 2 与 3。灰线为按构造笔直的抽样条件路径；实线为精确边缘轨迹，虚线为相应从 z_0 到 z_1 的时间线性插值。二者可见差距说明边缘轨迹不随 t 仿射。左右边缘显示源与目标密度；图例另含速度场 $v^*(x,t)$。来源：作者借助 AI 辅助编程绘制。

5.4 （可选）典范仿射流的性质

给定端点分布 $p_0 = p_{\text{src}}$、$p_1 = p_{\text{tgt}}$，流匹配（Lipman et al., 2022）与整流流（RF）（Liu, Gong, et al., 2022）常用的自然选择是线性插值：$a_t = 1 - t, b_t = t$，得到

$$x_t = (1-t)x_0 + tx_1, \qquad x_0 \sim p_{\text{src}}, \quad x_1 \sim p_{\text{tgt}},$$
$$\mathcal{L}(\phi) = \mathbb{E}_{t\sim\mathcal{U}[0,1]}\mathbb{E}_{x_0,x_1}\left[\|v_\phi(x_t,t) - (x_1 - x_0)\|_2^2\right].$$

这种线性流具有若干吸引人的性质，特别是存在称为 Reflow 的迭代改进方法，在保持边缘分布的同时逐步拉直分布之间的路径。

5.4.1 流的整流：从带噪猜测到有结构的配对

为何改变耦合？ 在独立耦合 $\pi(x_0, x_1) = p_{\text{src}}(x_0)p_{\text{tgt}}(x_1)$ 下，每条条件插值都是直线。但正如原文第 5.4 节所强调的，[13]相应边缘速度平均许多无关端点对的方向，因此诱导的边缘 ODE 轨迹未必笔直。仅用少量数值步时，这些弯曲动力学可能较难精确积分。

整流通过改变端点耦合处理这一问题：学得的 ODE 把每个源样本输运到一个模型生成的端点，形成有依赖的耦合，随后用它定义新的条件插值。

用依赖耦合整流。 不再任意配对，而以预训练扩散模型 $v_{\phi^\times}(\cdot, t)$ 为 PF-ODE 漂移，确定性输运各源点。从 $z(0) = z_0 \sim p_{\text{src}}$ 积分

$$\frac{dz(t)}{dt} = v_{\phi^\times}(z(t), t), \qquad t \in [0,1],$$

得到 $\widehat{z}_1 := z(1)$，位于预训练模型学到的数据空间附近。$(z_0, \widehat{z}_1)$ 因而构成依赖耦合，遵循模型引导的结构化路径。这一思想自然推广到参考路径 $x_t = a_t x_0 + b_t x_1$，端点分别来自源与目标。

算法 2 Rectify（整流）操作

Require: 参考路径 $\{x_t\}_{t\in[0,1]}$，例如 $x_t = a_t x_0 + b_t x_1$

1: **预训练扩散模型**。在所选路径上拟合

$$\phi^\times \in \arg\min_\phi \mathbb{E}_{t,x_0,x_1}\left[\left\|v_\phi(x_t,t) - \frac{dx_t}{dt}\right\|_2^2\right].$$

2: **整流**。抽取 $z_0 \sim p_{\text{src}}$，积分 $dz(t)/dt = v_{\phi^\times}(z(t), t)$，$z(0) = z_0$，$t \in [0,1]$，得到 $\widehat{z}_1 = z(1)$ 与整条轨迹。

Ensure: 依赖的（一致的）端点对 $(z_0, \widehat{z}_1)$，或完整轨迹

为何有效：保持边缘的结构。 记上述预训练模型 ODE 的流映射为 $\Phi_{0\to t}$，则 $z(t) = \Phi_{0\to t}(z_0)$、$\widehat{z}_1 = \Phi_{0\to 1}(z_0)$。Rectify 将每个源点与其流端点配对，给出确定性联合分布

$$\pi_{\text{Rectify}}(z_0, z_1) = p_{\text{src}}(z_0)\delta(z_1 - \Phi_{0\to 1}(z_0)).$$

立即有两个结果：

[13]译注：原文在此引用第 5.4 节；明确区分条件直线与边缘流直线的论证及反例见上一小节。

- 保持源边缘：$\int \pi_{\text{Rectify}}(z_0, z_1)\, dz_1 = p_{\text{src}}(z_0)$；
- 沿流推前：$(\Phi_{0\to t})\sharp p_{\text{src}} = \text{Law}(z(t))$，即各时刻分布是源分布经流映射的推前。

若 $v_{\phi^\times}$ 精确匹配参考路径的理想漂移，则全部中间边缘相同：

$$\text{Law}(z(t)) = \text{Law}(x_t), \quad t \in [0,1], \qquad\qquad (\Phi_{0\to 1})\sharp p_{\text{src}} = p_{\text{tgt}}.$$

小结。 整流以学得流诱导的耦合替代独立耦合。反复 Reflow 可使边缘输运越来越容易用少量数值步积分。对典范路径，反复 Rectify 还会在不增加输运代价的情况下拉直轨迹，使训练更容易。[14]

5.4.2 Reflow：迭代拉直流

为何 Reflow？ 独立配对常在源与目标之间诱导不规则、曲折的 ODE 轨迹，增大模拟的离散化误差与方差。于是有如下问题：

> **问题 5.4.1：** 能否学到一种耦合，在仍保持正确边缘的同时，使两分布间输运路径更接近直线？

Reflow 就是反复 Rectify 以更新耦合，使后续的流更易积分。

核心思想：通过 Rectify 递归拉直。 从乘积耦合 $\pi^{(0)} := p_{\text{src}}(x_0)p_{\text{tgt}}(x_1)$ 上的典范插值 $x_t = (1-t)x_0 + tx_1$ 开始。Rectify 用学得 ODE 诱导的依赖端点对替代独立配对。重复此操作通常使轨迹更直，少量数值步也易准确积分；精确保证见第 5.4.3 节。

Reflow 过程。 每轮包含两步：

1. **重新拟合流**。用当前耦合的样本训练新速度：

$$\phi_{k+1} = \arg\min_{\phi} \mathcal{L}(\phi \mid \pi^{(k)}),$$

其中

$$\mathcal{L}(\phi \mid \pi^{(k)}) := \mathbb{E}_{t,(z_0^{(k)},\widehat{z}_1^{(k)})\sim\pi^{(k)}} \left[\left\| v_\phi(z_t, t) - (\widehat{z}_1^{(k)} - z_0^{(k)}) \right\|^2 \right], \tag{5.4.1}$$

$z_t = (1-t)z_0^{(k)} + t\widehat{z}_1^{(k)}$。

2. **生成新耦合**。从新源样本 $z_0^{(k+1)} \sim p_{\text{src}}$ 出发求解学得 ODE：

$$\widehat{z}_1^{(k+1)} \leftarrow z_0^{(k+1)} + \int_0^1 v_{\phi_{k+1}}(z(t), t)\, dt,$$
$$\pi^{(k+1)}(z_0, z_1) := p_{\text{src}}(z_0)\delta(z_1 - \widehat{z}_1^{(k+1)}).$$

换言之，Reflow 反复作用 Rectify 算子，生成逐步改进的耦合序列：

$$\pi^{(k+1)} = \text{Rectify}(\pi^{(k)}). \tag{5.4.2}$$

流与耦合共同演化，得到逐渐更稳定的输运路径。

[14] 译注：上述精确边缘保持依赖理想漂移条件，实际学习与数值积分仍有误差。

5.4.3 Reflow 的性质

Reflow 的作用来自两个关键理论性质：降低输运代价与拉直轨迹。

一、**Reflow 不增加输运代价**。 令 $c(y)$ 为凸代价，例如 $\|y\|_2^p$、$p \geq 1$。每次 Rectify 形成的新耦合的代价不超过原耦合。

命题 5.4.1 (Rectify 可能降低输运代价)**.** *假设速度理想，即 $v^* = v_{\phi^\times}$，则*

$$\mathbb{E}[c(\widehat{z}_1 - z_0)] \leq \mathbb{E}[c(x_1 - x_0)].$$

证明. 由 Jensen 不等式得到；完整推导见 Liu, Gong, et al. (2022)。 □

递归应用表明，Reflow 不增加输运代价。

二、**Reflow 拉直路径**。 递归 Reflow 促进轨迹变直，但不保证每轮直线性度量都单调改善。定义路径 $\mathbf{Y} = \{y_t\}_{t\in[0,1]}$ 的直线性泛函：

$$\mathcal{S}(\mathbf{Y}) := \int_0^1 \mathbb{E}\left[\left\| y_1 - y_0 - \frac{dy_t}{dt} \right\|_2^2\right] dt.$$

$\mathcal{S}(\mathbf{Y}) = 0$ 时，$\mathbf{Y}$ 是精确直线。

命题 5.4.2 (Reflow 拉直随机路径)**.** *对整流路径 $\mathbf{Z}^{(k)}$，有*

$$\min_{k\in\{0,\ldots,K\}} \mathcal{S}(\mathbf{Z}^{(k)}) \leq \frac{\mathbb{E}[\|x_1 - x_0\|^2]}{K}.$$

证明. 见 Liu, Gong, et al. (2022) 的定理 3.7。 □

译注：式中需 $K \geq 1$，且右端二阶矩有限才给有限上界；它控制前若干轮中的最小值，并非每轮单调变直。此处理论结论沿上文的理想速度与精确流设定，不自动涵盖有限样本、有限网络或数值离散误差。线性插值核的 FM / RF 加上 Reflow，既给出简单训练目标，也提供改进随机耦合的实用方法。理论细节见 Liu, Gong, et al. (2022)、Liu (2022)。

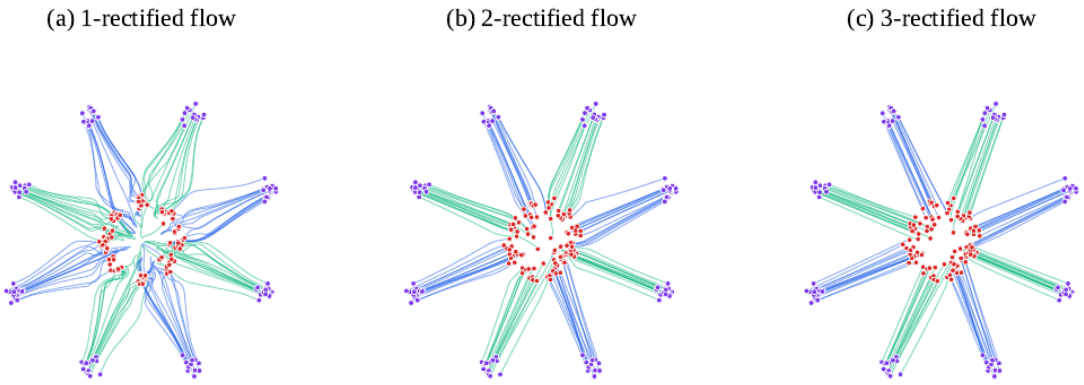


图 5.11: Reflow 示意。经过 Rectify，路径逐渐变直；(a) 一次整流流，(b) 二次整流流，(c) 三次整流流。来源：改编自 Liu, Gong, et al. (2022)。

三、**与最优传输的联系**。 直线耦合未必在最优传输（OT）意义下最优。不熟悉 OT 的读者可先看原书第 7.2 节的术语。

二次代价 OT 的一个特征是粒子沿直线从 x_0 走向最优映射 $T(x_0)$：$x_t = (1-t)x_0 + tT(x_0)$。但并非任意映射 S 生成的直线路径都最优；仅当 S 最小化 Monge 代价 $\mathbb{E}[\|x_0 - S(x_0)\|^2]$，它才给出最优流。所以直线路径必要而不充分，还需正确的端点映射。

例：直线耦合不必最优。 令 $p_{\text{src}} = p_{\text{tgt}} = \mathcal{N}(0, I)$。对 $c(x, y) = \|x - y\|^p$、$p > 0$，最优耦合为恒等耦合，即 $x \sim p_{\text{src}}$ 时 (x, x) 的分布。再考虑 (x, Ax) 的分布 π_A，其中旋转矩阵满足 $A^\top A = I$、$\det A = 1$、$A \neq I$，且 -1 不是其特征值。它是端点分布的有效耦合，对应从 x 到 Ax 的直线路径，但原文指出，对任何二次可微、严格凸且 Hessian 可逆的代价 c，它都不是 c 最优。次优性来自旋转变换。如原式 7.5.2 所述，甚至移除旋转也未必使耦合最优。[15] 原书第 7.5.2 节继续讨论与 OT 的联系。

5.5 结束语

本章介绍扩散模型第三种、也是最后一种基础视角：确定性流。从利用变量替换公式学习简单先验与数据之间精确可逆映射的 NF 开始，我们走向连续时间的神经 ODE，以学得速度场控制变换。但这种方法的显著缺点是训练循环内需要昂贵的 ODE 模拟。

流匹配为此提供简洁、高效的方法。预先定义概率路径与满足连续性方程的相应速度场，就为 ODE 流建立明确目标。与变分和得分视角一样，关键的条件化技巧把匹配难计算边缘速度的问题，变为对已知条件速度的简单、可计算回归，使训练无需模拟。从这个角度，扩散模型是学习确定性流、把高斯先验输运为数据分布的特例。

至此，扩散建模的三根概念支柱已介绍完毕。尽管各自起源于 VAE、EBM 或 NF，它们都走向连续时间生成过程，并都依靠条件化策略实现可计算学习。下一章把三条线索综合成统一框架：

1. 正式说明变分、得分与流视角在基础层面具有数学等价性；
2. 说明 Fokker–Planck 方程如何成为三种视角中支配密度演化的共同规律，揭示其描述同一核心生成原理。

这一统一视角将提供对现代扩散范式完整而系统的理解。

[15] 译注：本段由明确的位移范数代价转到笼统的 c，后者的自变量和结构条件未在此进一步说明，不能据此扩大到任意一般二元代价；保留其原表述与后文定位。直线性的必要性在本段二次代价位移插值 / 动力学表述中理解，并非静态端点耦合自身额外规定了所有可能的时间参数化。

第六章　统一而系统的扩散模型视角

数学是一门给不同事物赋予同一名称的艺术。
Henri Poincaré

本章将变分、得分与流视角联系为一个连贯图景。尽管这些方法出于不同直觉，它们最终汇聚到现代扩散模型的同一核心机制：定义一个沿边缘分布路径演化的正向污染过程，再学习构造沿该路径逆向运行的生成动力学所需的局部量。回顾第 2–5 章，可以看到一个共同配方：定义描绘边缘分布路径的正向污染过程，再学习随时间变化的向量场，沿该路径把简单先验输运为数据分布。

贯穿各视角的关键是第 6.1 节的条件化技巧：把难计算的边缘目标变为可计算的条件目标，从而实现稳定而高效的训练。第 6.2 节系统分析训练目标，识别其基本组成，说明变分、得分与流视角下的损失如何形成。第 6.3 节说明，形如 $x_t = \alpha_t x_0 + \sigma_t \epsilon$ 的仿射正向加噪可等价变换到标准线性调度 $x_t = (1-t)x_0 + t\epsilon$；噪声、干净数据、得分与速度预测等常见参数化，也可在梯度层面相互转换。因此，噪声调度与参数化的选择遵循同一建模原理。最后，第 6.4 节把讨论归结为支配规则：Fokker–Planck 方程。无论把方法看作变分方案（离散时间去噪）、得分方法（SDE）还是流方法（ODE），它们都构造使边缘遵循同一密度演化的生成器。Fokker–Planck 方程是三种视角共同遵守的约束，差异则来自参数化与训练目标。

学完本章后，你将能够：

- 识别变分、得分与流训练背后的共同条件化原理：通过可计算条件目标学习难计算边缘目标；
- 理解干净数据、噪声、得分与速度四种常用预测，在正向调度非退化时转换其理想预测；
- 分清正向噪声调度、预测目标、时间采样分布和时间权重等主要设计选择，区分数学重参数化与仍会影响实际优化的改变；
- 区分不同的 “等价”：表示相同理想信息、总体目标在权重或加法常数意义下等价、描绘相同边缘密度路径，以及实际训练或采样算法行为相同；
- 理解仿射概率路径经时间重参数化与空间缩放联系起来时，哪些量保持、哪些量不保持；
- 理解连续性方程与 Fokker–Planck 方程如何从密度层面联系变分、确定性 ODE 及随机 SDE 描述。

阅读路线。 本章是全书概念上的拱心石。初读应关注条件化原理、四种预测的关系，以及连接三种视角的连续性方程/Fokker–Planck 图景。重点不是背下所有换算公式，而是追问当前使用哪种等价、它究竟保持什么。随后可重读权重、调度和参数化的细致分析，理解数学等价的表述为何在实践中仍会表现不同。

6.1 条件化技巧：扩散模型的秘诀

此前从三个看似不同的起点研究扩散模型：变分、得分与流视角。它们最初目标不同，导出各自的训练目标（固定 t）：

- **变分视角：** 学习参数密度 $p_\phi(x_{t-\Delta t} \mid x_t)$，以近似理想逆转移 $p(x_{t-\Delta t} \mid x_t)$，最小化

$$\mathcal{J}_{\mathrm{KL}}(\phi) := \mathbb{E}_{p_t(x_t)}\left[D_{\mathrm{KL}}\big(p(x_{t-\Delta t} \mid x_t) \| p_\phi(x_{t-\Delta t} \mid x_t)\big)\right].$$

- **得分视角：** 学习 $s_\phi(x_t, t)$ 近似边缘得分 $\nabla_x \log p_t(x_t)$：

$$\mathcal{J}_{\mathrm{SM}}(\phi) := \mathbb{E}_{p_t(x_t)}\left[\|s_\phi(x_t, t) - \nabla_x \log p_t(x_t)\|_2^2\right].$$

- **流视角：** 学习速度 $v_\phi(x_t, t)$ 匹配理想速度 $v_t(x_t)$（例如式 (5.2.9)），最小化

$$\mathcal{J}_{\mathrm{FM}}(\phi) := \mathbb{E}_{p_t(x_t)}\left[\|v_\phi(x_t, t) - v_t(x_t)\|_2^2\right].$$

乍看这些目标都难以计算，因为它们需要一般情况下无法获得的理想量。转机在于：各方法独立找到了同一个巧妙解法——以数据 x_0 为条件，把难计算目标变成可计算目标。条件化技巧将目标重写为已知高斯条件分布 $p_t(x_t \mid x_0)$ 上的期望，得到与边缘版本梯度等价的条件目标：

- **变分视角**（式 (2.2.3)）：

$$\mathcal{J}_{\mathrm{KL}}(\phi) = \underbrace{\mathbb{E}_{x_0}\mathbb{E}_{p_t(x_t|x_0)}\left[D_{\mathrm{KL}}\big(p(x_{t-\Delta t} \mid x_t, x_0) \| p_\phi(x_{t-\Delta t} \mid x_t)\big)\right]}_{\mathcal{J}_{\mathrm{CKL}}(\phi)} + C.$$

- **得分视角**（式 (3.3.3)）：

$$\mathcal{J}_{\mathrm{SM}}(\phi) = \underbrace{\mathbb{E}_{x_0}\mathbb{E}_{p_t(x_t|x_0)}\left[\|s_\phi(x_t, t) - \nabla_{x_t} \log p_t(x_t \mid x_0)\|_2^2\right]}_{\mathcal{J}_{\mathrm{DSM}}(\phi)} + C.$$

- **流视角**（式 (5.2.10)）：

$$\mathcal{J}_{\mathrm{FM}}(\phi) = \underbrace{\mathbb{E}_{x_0}\mathbb{E}_{p_t(x_t|x_0)}\left[\|v_\phi(x_t, t) - v_t(x_t \mid x_0)\|^2\right]}_{\mathcal{J}_{\mathrm{CFM}}(\phi)} + C.$$

下面系统重访条件 KL、得分与速度目标。重要的是，这些目标不仅可计算，而且与原目标仅相差常数竖直平移。条件版本 $\mathcal{J}_{\mathrm{CKL}}, \mathcal{J}_{\mathrm{DSM}}, \mathcal{J}_{\mathrm{CFM}}$ 与原版本 $\mathcal{J}_{\mathrm{KL}}, \mathcal{J}_{\mathrm{SM}}, \mathcal{J}_{\mathrm{FM}}$ 之差不依赖模型参数，因此在同一模型类中有相同的极小化解。

为理解理想极小化解恢复什么，假设模型表达力足以精确表示理想量。三种视角于是遵循同一模式：

$$\underbrace{\text{边缘理想量}}_{\text{一般难计算}} = \mathbb{E}_{x_0\sim p(\cdot|x_t)}\left[\underbrace{\text{条件理想量}}_{\text{给定}x_0\text{后可计算}}\right].$$

给定干净样本 x_0 得到可计算目标，再对与 x_t 相容的干净样本平均，恢复所需边缘理想量。具体为

$$\begin{aligned} p^*(x_{t-\Delta t}\mid x_t) &= \mathbb{E}_{x_0\sim p(\cdot|x_t)}[p(x_{t-\Delta t}\mid x_t,x_0)] = p(x_{t-\Delta t}\mid x_t),\\ s^*(x_t,t) &= \mathbb{E}_{x_0\sim p(\cdot|x_t)}[\nabla_{x_t}\log p_t(x_t\mid x_0)] = \nabla_{x_t}\log p_t(x_t),\\ v^*(x_t,t) &= \mathbb{E}_{x_0\sim p(\cdot|x_t)}[v_t(x_t\mid x_0)] = v_t(x_t). \end{aligned} \tag{6.1.1}$$

变分视角的第一式来自对 x_0 边缘化条件逆转移；KL 在所得边缘逆转移处最小。得分与速度的平方误差是最小二乘回归，其总体极小化解为相应条件期望。这些恒等式描述不受限总体理想量，受限神经网络未必能精确表示它们。

例：有限数据集上的闭式理想目标。 为使式 (6.1.1) 更具体，设数据分布为经验测度

$$\widehat{p}_0 = \frac{1}{N}\sum_{i=1}^{N}\delta_{x_0^{(i)}},$$

其中 $\{x_0^{(i)}\}_{i=1}^N$ 为有限训练集。式 (6.1.1) 中 $x_0\sim p(\cdot\mid x_t)$ 表示对给定含噪观测 x_t 后干净样本的后验取平均。等价地，对任意量 $h(x_0)$，

$$\mathbb{E}_{x_0\sim p(\cdot|x_t)}[h(x_0)] = \int h(x_0)p(x_0\mid x_t)\,dx_0.$$

由 Bayes 公式，

$$p(x_0\mid x_t) = \frac{p_t(x_t\mid x_0)p_{\text{data}}(x_0)}{\int p_t(x_t\mid \widetilde{x}_0)p_{\text{data}}(\widetilde{x}_0)\,d\widetilde{x}_0}.$$

标准高斯扩散正向过程满足

$$p_t(x_t\mid x_0^{(i)}) = \mathcal{N}(x_t;\alpha_t x_0^{(i)},\sigma_t^2 I),$$

所以条件似然显式已知。但在总体层面，后验 $p(x_0\mid x_t)$ 仍需对完整数据分布 p_{data} 平均。若现在以经验测度 $\widehat{p}_0 = N^{-1}\sum_i \delta_{x_0^{(i)}}$ 替代 p_{data}，后验只支撑于训练样本，在 $x_0^{(i)}$ 处的质量为

$$p(x_0 = x_0^{(i)}\mid x_t) = \frac{p_t(x_t\mid x_0^{(i)})}{\sum_{j=1}^N p_t(x_t\mid x_0^{(j)})} =: w_i(x_t,t), \qquad \sum_{i=1}^N w_i(x_t,t) = 1.$$

因此后验期望化为有限求和

$$\mathbb{E}_{x_0\sim p(\cdot|x_t)}[h(x_0)] = \sum_{i=1}^N w_i(x_t,t)h(x_0^{(i)}).$$

式 (6.1.1) 中的抽象后验平均，成为训练集上权重为 $w_i(x_t,t)$ 的具体加权平均。下面分别写出三种情形。

变分视角。 理想逆转移为

$$p^*(x_{t-\Delta t} \mid x_t) = \sum_{i=1}^{N} w_i(x_t, t) p(x_{t-\Delta t} \mid x_t, x_0^{(i)}).$$

高斯扩散下，各条件逆核 $p(x_{t-\Delta t} \mid x_t, x_0^{(i)})$ 也有闭式；引理 2.2.2 已表明它是高斯。因此真实逆核就是显式高斯桥的后验加权混合。[1]

得分视角。 同样，理想得分为

$$s^*(x_t, t) = \sum_{i=1}^{N} w_i(x_t, t) \nabla_{x_t} \log p_t(x_t \mid x_0^{(i)}).$$

条件得分显式为

$$\nabla_{x_t} \log p_t(x_t \mid x_0^{(i)}) = -\frac{x_t - \alpha_t x_0^{(i)}}{\sigma_t^2},$$

因而

$$s^*(x_t, t) = -\frac{1}{\sigma_t^2} \left(x_t - \alpha_t \sum_{i=1}^{N} w_i(x_t, t) x_0^{(i)} \right).$$

边缘得分从含噪样本指向训练样本的后验加权平均。

流视角。 流匹配也有同一现象：

$$v^*(x_t, t) = \sum_{i=1}^{N} w_i(x_t, t) v_t(x_t \mid x_0^{(i)}).$$

构成项同样显式已知，相应条件速度场的闭式为

$$v_t(x_t \mid x_0^{(i)}) = \alpha_t' x_0^{(i)} + \frac{\sigma_t'}{\sigma_t}(x_t - \alpha_t x_0^{(i)}).$$

因此理想速度也是数据集上的显式后验加权平均。综上，有限数据集上三种理想目标都化为闭式条件量的显式后验加权平均。

关于记忆的说明。 这些公式刻画由经验分布 $\widehat{p}_0$ 而非未知总体分布 p_{data} 诱导的精确理想目标。若模型在每个噪声水平都完美学得经验目标，且逆过程计算没有误差，生成便会精确恢复 $\widehat{p}_0$。由于它只给训练样本分配概率，生成样本将来自训练集本身。在此理想化意义下，完美拟合经验理想量等同于记忆。

但实际训练的扩散模型未必精确实现该理想量：模型容量与优化有限，生成分布还受模型近似和数值采样误差影响。因此，有限数据集计算证明记忆是一个精确经验解，并不意味着所有实际训练模型都必然记住训练集。

共同的条件重写并非巧合：在使训练可计算的同时，它揭示了深层统一。变分扩散、得分 SDE 和流匹配只是同一原理的不同侧面。三种视角，由同一个洞见联系起来；本章余下部分继续研究它们的等价。

[1]译注：有关高斯密度与条件得分的表达式在非退化噪声处使用；逆核到达零噪声端点时可退化为点质量，不能将其统一视为具有正方差的高斯密度。经验测度上的积分按测度积分或上述有限求和理解。

6.2 理清扩散模型训练损失的路线图

本节系统研究训练损失。第 6.2.1 节把三个标准目标扩展为四种参数化，说明其不同建模来源；第 6.2.2 节提炼一般框架，拆解目标结构，为第 6.3 节的等价结果奠基。

6.2.1 四种常见参数化

除非另有说明，采用式 (4.5.1) 的正向扰动核

$$p_t(x_t \mid x_0) = \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I), \qquad x_0 \sim p_{\text{data}}.$$

令 $\omega : [0, T] \to \mathbb{R}_{>0}$ 为正时间权重。下面总结噪声 ϵ_ϕ、干净样本 x_ϕ、得分 s_ϕ 和速度 v_ϕ 四种参数化及其极小化解 $\epsilon^*, x^*, s^*, v^*$，便于后续讨论。

变分视角。 基于 DDPM 的 KL 散度（第 2.2.4 和 4.5.2 节），该方法归结为预测产生 x_t 的期望噪声，或被扰动为 x_t 的期望干净信号。

1. ϵ **预测（噪声预测）**（Ho et al., 2020）：

$$\epsilon_\phi(x_t, t) \approx \mathbb{E}[\epsilon \mid x_t] = \epsilon^*(x_t, t). \tag{6.2.1}$$

训练目标为

$$\mathcal{L}_{\text{noise}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{x_0, \epsilon} \| \epsilon_\phi(x_t, t) - \epsilon \|_2^2 \right].$$

ϵ^* 是为得到给定 x_t 而注入的平均噪声。

2. x **预测（干净样本预测）**（Kingma et al., 2021; Karras et al., 2022; Song et al., 2023）：

$$x_\phi(x_t, t) \approx \mathbb{E}[x_0 \mid x_t] = x^*(x_t, t). \tag{6.2.2}$$

训练目标为

$$\mathcal{L}_{\text{clean}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{x_0, \epsilon} \| x_\phi(x_t, t) - x_0 \|_2^2 \right].$$

x^* 是给定含噪观测 x_t 后所有合理干净猜测的平均。

得分视角。 预测噪声水平 t 的得分，它指向把 x_t 去噪、返回可能产生它的各个干净样本的平均方向：

3. **得分预测**（Song and Ermon, 2019; Song et al., 2020c）：

$$\begin{aligned} s_\phi(x_t, t) &\approx \nabla_{x_t} \log p_t(x_t) \\ &= \mathbb{E}[\nabla_{x_t} \log p_t(x_t \mid x_0) \mid x_t] = s^*(x_t, t). \end{aligned} \tag{6.2.3}$$

训练目标为

$$\mathcal{L}_{\text{score}}(\phi) := \mathbb{E}_t \left[\omega(t) \mathbb{E}_{x_0, \epsilon} \| s_\phi(x_t, t) - \nabla_{x_t} \log p_t(x_t \mid x_0) \|_2^2 \right],$$

其中条件得分满足 $\nabla_{x_t} \log p_t(x_t \mid x_0) = -\epsilon / \sigma_t$。

流视角。 预测数据通过 x_t 演化时的瞬时平均速度：

4. v **预测（速度预测）**（Lipman et al., 2022; Liu, 2022; Salimans and Ho, 2021; Albergo et al., 2023）：

$$v_\phi(x_t,t) \approx \mathbb{E}\left[\left.\frac{dx_t}{dt}\right| x_t\right] = v^*(x_t,t). \tag{6.2.4}$$

训练目标为

$$\mathcal{L}_{\text{velocity}}(\phi) := \mathbb{E}_t\left[\omega(t)\mathbb{E}_{x_0,\epsilon}\|v_\phi(x_t,t) - v_t(x_t \mid x_0,\epsilon)\|_2^2\right],$$

其中条件速度为 $v_t(x_t \mid x_0,\epsilon) = \alpha_t' x_0 + \sigma_t'\epsilon$。$v^*$ 表示通过观测点 x_t 的平均速度向量。

根据式 (6.1.1)，四种预测最终都试图近似给定 x_t 后的条件期望，即平均噪声、干净数据、得分或速度。

6.2.2 拆解扩散模型的训练目标

四种预测通常共享以下训练模板：

$$\mathcal{L}(\phi) := \mathbb{E}_{x_0,\epsilon}\mathbb{E}_{p_{\text{time}}(t)}\left[\omega(t)\|\,\text{NN}_\phi(x_t,t) - (A_t x_0 + B_t\epsilon)\|_2^2\right]. \tag{6.2.5}$$

其中，p_{time} 是时间分布，$\omega(t)$ 是时间权重，平方范数是 MSE 部分。为提高训练效率、优化学习流程，以下设计至关重要（Karras et al., 2022; Lu and Song, 2024）：

(A) 通过 α_t, σ_t 指定 x_t 的正向噪声调度；

(B) 网络 NN_ϕ 的预测类型及相应回归目标 $A_t x_0 + B_t\epsilon$；

(C) 时间权重函数 $\omega : [0,T] \to \mathbb{R}_{\geq 0}$；

(D) 时间分布 p_{time}。

下面展开这四项，作为后文路线图。[2]

(A) 噪声调度 α_t, σ_t。 用户可针对应用选择调度，常见例子见表 5.2。式 (6.3.3)、(6.3.5) 将说明，形如 $x_t = \alpha_t x_0 + \sigma_t\epsilon$ 的仿射流在数学上等价：经适当时间重参数化与空间缩放，可变为规范线性调度 $\alpha_t = 1 - t, \sigma_t = t$，或三角调度 $\alpha_t = \cos t, \sigma_t = \sin t$。

(B) 参数化 NN_ϕ **与训练目标** $A_t x_0 + B_t\epsilon$。 扩散训练常把两项选择耦合：网络直接预测什么、损失比较什么。干净数据、噪声、得分与速度都可用于其中任一角色。

预测与损失匹配。 式 (6.2.5) 的常用选择，是直接按网络输出的预测类型训练。每种类型都有形如 $A_t x_0 + B_t\epsilon$ 的条件目标，系数取决于预测类型与正向调度，见表 6.1。例如，x 预测网络与干净目标 x_0 比较，v 预测网络则与条件速度 $v_t = \alpha_t' x_0 + \sigma_t'\epsilon$ 比较。式 (6.3.1) 将表明，这四种预测编码同一理想信息，并可相互转换。

[2]译注：本节源文先把 (C) 列为时间权重、(D) 列为时间分布，展开时又交换二者顺序。这里保留原列表与展开标题各自的编号，内容以标题为准。

表 6.1: 不同参数化的关系。四种参数化在数学上等价，可由直接代数运算相互转换。回归目标统一为 $A_t x_0 + B_t \epsilon$。

预测目标	A_t	B_t
干净样本	1	0
噪声	0	1
条件得分	0	$-1/\sigma_t$
条件速度	α_t'	σ_t'

预测一种量，用另一种量评价损失。 网络输出和损失所用量也可分开选择。先依式 (6.3.1) 转换预测，再与转换后类型的相应目标比较。例如，在规范调度 $x_t = (1-t)x_0 + t\epsilon$ 下，若网络直接预测干净数据 $x_\phi(x_t, t)$，转换成速度得到

$$v_\phi(x_t, t) = \frac{x_t - x_\phi(x_t, t)}{t}, \qquad v_t = \frac{x_t - x_0}{t},$$
$$\|v_\phi(x_t, t) - v_t\|_2^2 = \frac{1}{t^2}\|x_\phi(x_t, t) - x_0\|_2^2.$$

因此，固定网络输出为干净预测时，评价速度损失恰好等于给干净预测损失再乘时间权重。一般仿射调度与其他预测的关系见式 (6.3.6)。

改变网络直接预测的量还有额外影响。理想预测虽能代数转换，有限神经网络却要表示不同函数，输出尺度和参数梯度也不同。因此，预测选择会与架构及优化相互作用，损失选择则控制不同噪声水平上预测误差的相对权重。为清楚起见，除非另有说明，式 (6.2.5) 使用预测与损失匹配的情形。

(C) 时间分布 $p_{\text{time}}(t)$。 下面考虑训练中如何采样时间 t，也就是噪声水平。定义固定时间回归损失

$$\mathcal{L}_t(\phi) := \mathbb{E}_{x_0,\epsilon}\| \mathrm{NN}_\phi(x_t, t) - (A_t x_0 + B_t \epsilon)\|_2^2, \qquad x_t = \alpha_t x_0 + \sigma_t \epsilon.$$

式 (6.2.5) 可简写为

$$\mathcal{L}(\phi) = \mathbb{E}_{t\sim p_{\text{time}}}[\omega(t)\mathcal{L}_t(\phi)].$$

若不作校正，某些时间采样越频繁，它们在目标中的权重也越大。在精确期望损失层面，只有乘积 $p_{\text{time}}(t)\omega(t)$ 起作用。

非均匀采样的另一种用途是重要性采样。固定上述目标，改从提议分布 $q_{\text{time}}(t)$ 抽取时间，则

$$\mathcal{L}(\phi) = \mathbb{E}_{t\sim q_{\text{time}}}\left[\frac{p_{\text{time}}(t)}{q_{\text{time}}(t)}\omega(t)\mathcal{L}_t(\phi)\right],$$

条件是 $p_{\text{time}}(t)\omega(t) > 0$ 的地方都有 $q_{\text{time}}(t) > 0$。有此校正，改变 q_{time} 不改变目标，只改变 Monte Carlo 估计量，例如其方差。关键区别为

$$\text{改变目标中的}p_{\text{time}} \implies \text{权重不同，目标不同，}$$
$$\text{改变}q_{\text{time}}\text{ 并作重要性校正} \implies \text{目标相同，估计量不同.}$$

因此在概念上将时间采样与损失权重分开。均匀时间采样的密度只贡献常数因子，使这一区别不明显；非均匀采样则必须说明，分布是在定义目标，还是仅充当重要性采样提议。

两者都见于扩散训练。ScoreFlow 明确用重要性采样降低固定似然加权目标的方差（Song et al., 2021）。VDM 及后续分析同样表明，固定噪声水平坐标中的目标时，噪声调度可充当重要性采样分布（Kingma et al., 2021; Kingma and Gao, 2023）。相较之下，EDM（Karras et al., 2022）同时指定非均匀噪声水平训练分布与单独损失权重，两者共同决定有效训练权重。

(D) 时间权重函数 $\omega(t)$。 固定 p_{time} 后，$\omega(t)$ 决定各时间对目标的相对贡献；综合上一段，有效权重为 $p_{\text{time}}(t)\omega(t)$。简单基线是均匀采样并取 $\omega(t) \equiv 1$，例如标准简化的噪声预测及 FM/RF 目标（Ho et al., 2020; Lipman et al., 2022; Liu, 2022）。其他权重强调不同噪声区间，也可有似然或变分解释。例如，得分匹配的似然权重 $\omega(t) = g^2(t)$ 在适当正则条件下给出负对数似然的上界（Song et al., 2021）。更一般地，依赖 SNR 的权重是重新分配不同噪声水平训练重点的常用途径（Kingma et al., 2021; Kingma and Gao, 2023）。

单调权重与带增强的 ELBO 视角。 可用对数信噪比（log-SNR）描述污染程度：

$$\Lambda_t := \log \frac{\alpha_t^2}{\sigma_t^2}.$$

以 Λ 表示完整 log-SNR，区别于第 9 章的半 log-SNR 坐标 $\lambda_t = \log(\alpha_t/\sigma_t) = \Lambda_t/2$。正向过程噪声增加时 Λ_t 下降。把损失写为共同预测参数化后，令 $w(\Lambda)$ 表示分配给各 log-SNR 水平的有效权重。

Kingma and Gao (2023) 的一个有用结果是：若 $w(\Lambda)$ 随 Λ 非增（等价地，正向过程噪声越大，权重不下降），则加权扩散目标可重写为高斯扰动数据上的平均负 ELBO，至多相差与模型参数无关的项。[3] 单调权重因此有具体概率解释：不仅是偏重某些噪声水平，还相当于对不同污染强度的高斯污染数据进行变分训练并取平均。

小结。 对本书而言，主要教训是：许多表面上的训练设计选择，可通过它们如何改变噪声水平上的有效权重来理解。该权重影响实际优化景观，在单调权重等特殊情况下，还影响损失的变分解释。

---

[3]原注：为理解单调性，定义从噪声水平 t 起剩余的变分代价

$$\mathcal{L}(t; x_0) := D_{\mathrm{KL}}\big(p(x_{[t,T]} \mid x_0) \| p_\phi(x_{[t,T]})\big),$$

其中 $x_{[t,T]} := \{x_s\}_{s\in[t,T]}$ 为剩余连续扩散路径。这是从污染水平 t 开始、式 (2.2.13) 负 ELBO 的连续时间对应；更准确地，除与 ϕ 无关的项外，它等于扰动样本 x_t 的期望负 ELBO。对噪声预测，Kingma and Gao (2023) 给出

$$\frac{d}{dt}\mathcal{L}(t; x_0) = \frac{1}{2}\frac{d\Lambda_t}{dt}\mathbb{E}_\epsilon[\|\epsilon_\phi(x_t, t) - \epsilon\|_2^2].$$

故加权损失满足

$$-\int_0^T w(\Lambda_t)\frac{d}{dt}\mathcal{L}(t; x_0)\, dt = w(\Lambda_0)\mathcal{L}(0; x_0) + \int_0^T \frac{d}{dt} w(\Lambda_t)\mathcal{L}(t; x_0)\, dt + C.$$

C 与 ϕ 无关。Λ_t 随 t 下降，故 w 对 Λ 非增时，$\frac{d}{dt}w(\Lambda_t) \geq 0$。归一化后，上式各项形成不同高斯污染水平 ELBO 的非负加权，得到带高斯数据增强的 ELBO 解释。

6.3 扩散模型中的等价

许多扩散表述之所以看起来不同，是因为采用不同预测类型、训练目标、噪声调度或连续动力学。本节说明它们在精确理论层面何种意义下等价，以及学得模型的实际行为为何仍可能不同。在精确或理想层面，会出现几种等价：

- **预测**。给定含噪观测 x_t 和正向调度，干净数据、噪声、得分与速度理想量包含相同信息，可代数转换。
- **训练目标**。不同预测类型的平方误差可相差正的时间因子，同时共享逐点理想极小化解；这些因子决定不同噪声水平的训练权重。
- **仿射正向过程**。粒子层面的 $x_t = \alpha_t x_0 + \sigma_t \epsilon$ 可经状态缩放与相应规范坐标联系到规范仿射形式；该坐标随时间单调时，也定义时间重参数化。
- **边缘密度路径**。密度层面，不同确定性和随机动力学可产生同一边缘路径 $\{p_t\}_{t\in[0,T]}$。样本轨迹可不同，p_t 的演化则由相应连续性方程或 Fokker–Planck 方程支配。

从预测到采样逐步展开：第 6.3.1 节联系四种理想预测与损失；第 6.3.2 节给出同一理想 PF-ODE 的不同表达；第 6.3.3 节联系规范线性及三角路径；第 6.3.4 节讨论规范线性调度与速度预测的训练及数值积分含义。精确关系提供共同数学基础，实际选择仍有意义：有限网络近似等价理想量的方式不同，损失权重、优化、架构与数值积分可造成不同训练和采样行为。

6.3.1 四种预测类型等价

先分析式 (6.2.5) 的 (B)。四种预测不是独立选择，而是同一基本量的不同视角。例如，噪声与干净预测直接相关（第 2.2.4 节），得分与噪声预测也如此（第 3.4 节）。这一反复出现的模式指向更深原理：四种参数化可经简单变换相互转换。参照 Kingma et al. (2021)，把关系表为如下命题及图 6.1。

命题 6.3.1 (参数化等价)**.** *令 $\epsilon^*(x_t,t), x^*(x_t,t), s^*(x_t,t), v^*(x_t,t)$ 为分别极小化噪声、干净样本、得分及速度目标的最优预测。它们满足*

$$\begin{aligned} \epsilon^*(x_t,t) &= -\sigma_t s^*(x_t,t), \\ x^*(x_t,t) &= \frac{1}{\alpha_t} x_t + \frac{\sigma_t^2}{\alpha_t} s^*(x_t,t), \\ v^*(x_t,t) &= \alpha_t' x^* + \sigma_t' \epsilon^* = f(t) x_t - \frac{1}{2} g^2(t) s^*(x_t,t). \end{aligned} \tag{6.3.1}$$

$f(t), g(t)$ 与 α_t, σ_t 的关系由引理 4.5.1 给出；这些极小化解还满足式 (6.2.1)–(6.2.4)。

证明. 证明与定理 4.3.1 相似，后者分析 DSM 目标下各匹配损失的全局最优解。细节见附录 D.4。 □

译注： 互相恢复预测须在相关分母和转换系数非退化的时间使用，例如 $\alpha_t \neq 0$、$\sigma_t \neq 0$，从速度恢复其他量还需 $\alpha_t'\sigma_t - \alpha_t\sigma_t' \neq 0$。到奇异端点应另取适当极限；一般仿射调度若要对应实值扩散 SDE，还须所得 $g^2(t) \geq 0$。原命题的简写不免除这些条件。

本命题最自然地描述理想信息等价。给定噪声水平、含噪观测与调度，知道一个理想预测便可依式 (6.3.1) 确定其余预测。例如，得分确定后验均值干净预测，两者任一又确定 PF-ODE 速度。因此理想层面它们包含有关同一扩散过程的相同信息。但对学得模型，必须区分理想等价与

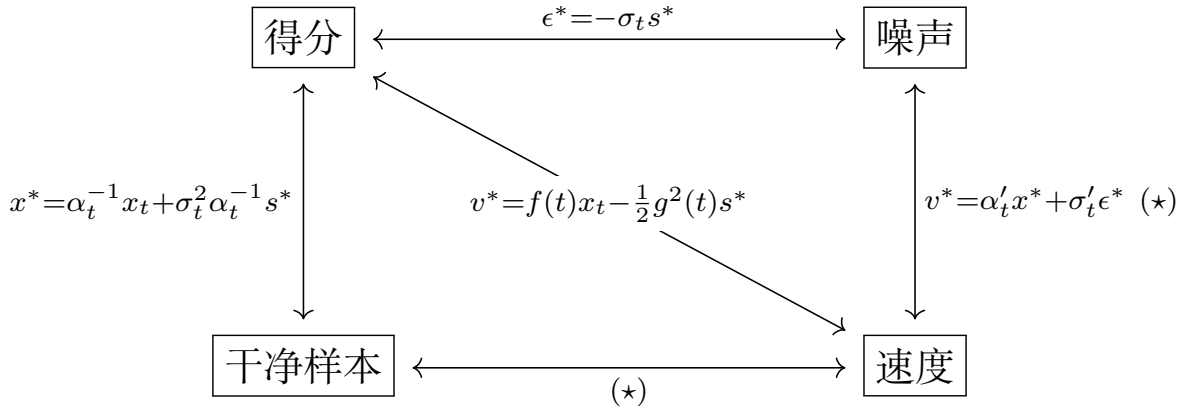


图 6.1: 四种理想参数化的等价关系。利用正向调度与观测状态 x_t，每种理想预测都可转换成其余类型。例如 $v^* = \alpha_t' x^* + \sigma_t' \epsilon^*$，而干净与噪声预测满足 $x_t = \alpha_t x^* + \sigma_t \epsilon^*$。来源：作者绘制；按源物理 198 页用可编辑数学箭头图重建。

网络直接预测什么。可任取 $\epsilon_\phi(x_t,t), x_\phi(x_t,t), s_\phi(x_t,t), v_\phi(x_t,t)$ 为网络输出；选定主预测后，其余量由同一代数换算定义。特别地，训练后参数 $\phi^\times$ 的换算预测按构造严格相容，例如

$$x = \alpha_t x_{\phi^\times}(x,t) + \sigma_t \epsilon_{\phi^\times}(x,t).$$

训练中及训练后都可利用换算，如把噪声预测转为逆 SDE 采样的得分或 PF-ODE 采样的速度。

网络参数化还应与训练损失区分。式 (6.2.5) 的 (B) 已说明，输出量不一定就是评价损失的量；可先换算再计算目标，一般会改变平方误差的时间权重，见式 (6.3.6)。对有限网络，这一区别尤其重要：理想目标信息等价，但直接预测不同量意味着表示、优化不同函数，目标也可能对噪声水平施加不同权重。因此，分别按不同预测参数化独立训练的模型，未必产生相同经验预测或相同 PF-ODE。命题只讨论理想预测携带的信息；网络输出参数化与训练目标仍是各自有意义的设计选择。

6.3.2 不同参数化下的 PF-ODE

PF-ODE 有得分、噪声、去噪数据与速度等价参数化。原则上可互换，实践中却会影响向量场的刚性、离散误差行为与优化难度。用高级 ODE 求解器快速采样时（第 9 章），常用噪声或干净预测，以契合求解器输入、减少误差累积；训练仅需少数函数评价的生成器时（第 11 章），干净或速度预测往往产生更平滑的目标及更好逐步一致性。下面用式 (6.3.1) 显式换算。

命题 6.3.2 (不同参数化下的 PF-ODE)**.** 设正向调度为 α_t, σ_t，导数为 $\alpha_t' = d\alpha_t/dt$、$\sigma_t' = d\sigma_t/dt$。

经验 *PF-ODE* 可写为等价形式

$$\begin{aligned}\frac{dx(t)}{dt} &= \frac{\alpha_t'}{\alpha_t}x(t) - \sigma_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\epsilon^*(x(t),t)\\ &= \frac{\sigma_t'}{\sigma_t}x(t) + \alpha_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)x^*(x(t),t)\\ &= \frac{\alpha_t'}{\alpha_t}x(t) + \sigma_t^2\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)s^*(x(t),t)\\ &= \alpha_t' x^*(x(t),t) + \sigma_t'\epsilon^*(x(t),t)\\ &= v^*(x(t),t).\end{aligned} \tag{6.3.2}$$

译注：原文在命题中称“经验”，公式却使用理想量星号；这里保留。若表示同一个训练后模型，须用由同一主输出换算的预测替代这些理想量，不能把独立训练的不同模型自动当作同一场。固定同一精确向量场时，纯代数改写本身不改变其刚性；前段实践差异还涉及近似、表示与数值实现。

回顾引理 4.5.1，令

$$\begin{aligned}f(t) &= \frac{\alpha_t'}{\alpha_t},\\ g^2(t) &= \frac{d}{dt}(\sigma_t^2) - 2\frac{\alpha_t'}{\alpha_t}\sigma_t^2 = 2\sigma_t\sigma_t' - 2\frac{\alpha_t'}{\alpha_t}\sigma_t^2,\end{aligned}$$

即可写成熟悉的得分 SDE 形式

$$\frac{dx(t)}{dt} = f(t)x(t) - \frac{1}{2}g^2(t)s^*(x(t),t).$$

为具体说明如何离散 PF-ODE 采样，第 9.2 节将给出广泛使用的 DDIM 方案，展示 Euler 离散化与 PF-ODE 的自然联系。

6.3.3 所有仿射流都等价

下面分析式 (6.2.5) 的 (A)。

状态层面的等价。 FM（Lipman et al., 2022）与 RF（Liu, 2022）常用规范插值

$$x_t^{\mathrm{FM}} = (1-t)x_0 + t\epsilon = x_0 + t(\epsilon - x_0),$$

其速度是常向量 $\epsilon - x_0$。这一选择的表面简单性并非本质：任意 $x_t = \alpha_t x_0 + \sigma_t\epsilon$ 可写成规范路径的时间重参数化及缩放版本。定义

$$c(t) := \alpha_t + \sigma_t, \qquad \tau(t) := \frac{\sigma_t}{\alpha_t + \sigma_t}, \qquad c(t) \neq 0.$$

直接代数重写得到

$$\begin{aligned}x_t &= \alpha_t x_0 + \sigma_t\epsilon\\ &= (\alpha_t + \sigma_t)\left(\frac{\alpha_t}{\alpha_t + \sigma_t}x_0 + \frac{\sigma_t}{\alpha_t + \sigma_t}\epsilon\right)\\ &= c(t)\big((1-\tau(t))x_0 + \tau(t)\epsilon\big) = c(t)x_{\tau(t)}^{\mathrm{FM}}.\end{aligned}$$

只要 $c(t)\neq 0$，每个仿射路径逐点都是规范路径的标量缩放。若在所考察区间上，$\tau(t)$ 还连续且严格单调，则 $t\mapsto\tau(t)$ 是真正的时间变量替换，两路径经时间重参数化和缩放 $c(t)$ 联系。通常正向扩散调度中，信噪比单调下降意味着 $\tau(t)$ 单调演化。

对速度，由链式法则，

$$\begin{aligned} v(x_t,t) &:= \frac{d}{dt}(\alpha_t x_0+\sigma_t\epsilon) = \frac{d}{dt}\big(c(t)x^{\mathrm{FM}}_{\tau(t)}\big)\\ &= c'(t)x^{\mathrm{FM}}_{\tau(t)} + c(t)\tau'(t)\,\frac{d}{ds}x^{\mathrm{FM}}_{s}\Big|_{s=\tau(t)}\\ &= c'(t)x^{\mathrm{FM}}_{\tau(t)} + c(t)\tau'(t)v^{\mathrm{FM}}(x^{\mathrm{FM}}_{\tau(t)},\tau(t)), \end{aligned}$$

因为规范路径上 $v^{\mathrm{FM}}(x^{\mathrm{FM}}_{\tau},\tau)=-x_0+\epsilon$。总结为：

命题 6.3.3 (仿射流等价)**.** 设 $x^{\mathrm{FM}}_t=(1-t)x_0+t\epsilon$、$x_t=\alpha_t x_0+\sigma_t\epsilon$，$c(t):=\alpha_t+\sigma_t\neq 0$、$\tau(t):=\sigma_t/(\alpha_t+\sigma_t)$。则

$$\begin{aligned} x_t &= c(t)x^{\mathrm{FM}}_{\tau(t)},\\ v(x_t,t) &= c'(t)x^{\mathrm{FM}}_{\tau(t)} + c(t)\tau'(t)v^{\mathrm{FM}}(x^{\mathrm{FM}}_{\tau(t)},\tau(t)). \end{aligned} \tag{6.3.3}$$

每个 $c(t)\neq 0$ 的仿射插值都有这一规范状态表示。若 $\tau(t)$ 还连续且严格单调，也可解释为时间重参数化与标量缩放。

译注：上述导数沿固定 (x_0,ϵ) 的条件粒子路径计算；条件路径可在同一状态相交，不能据此把条件速度当成唯一边缘速度。对同一联合路径条件化并取平均，才得到相应边缘场的链式换算。对通常非负调度，SNR 单调下降可给出所述坐标单调性；推广到任意有符号调度还须另核角度与坐标分支。

与三角流等价。 另一常用仿射流是三角插值（Salimans and Ho, 2021; Albergo et al., 2023; Lu and Song, 2024）。任意仿射流也可表成此形式。定义

$$x^{\mathrm{Trig}}_u := \cos(u)x_0+\sin(u)\epsilon. \tag{6.3.4}$$

令 $R_t:=\sqrt{\alpha_t^2+\sigma_t^2}>0$，选择角 τ_t 满足

$$\cos\tau_t=\frac{\alpha_t}{R_t},\qquad\qquad \sin\tau_t=\frac{\sigma_t}{R_t}.$$

于是

$$x_t=\alpha_t x_0+\sigma_t\epsilon = R_t\left(\frac{\alpha_t}{R_t}x_0+\frac{\sigma_t}{R_t}\epsilon\right)=R_t x^{\mathrm{Trig}}_{\tau_t}. \tag{6.3.5}$$

(α_t,σ_t) 是平面一点，除以 R_t 将其投到单位圆，确定角 τ_t 及状态 $x^{\mathrm{Trig}}_{\tau_t}$，半径则给出整体尺度。若所考察区间还能把 τ_t 选为连续严格单调函数，该状态表示也定义真正的时间重参数化。对 u 求导，三角速度为

$$v^{\mathrm{Trig}}_u=-\sin(u)x_0+\cos(u)\epsilon.$$

通过式 (6.3.5) 同一变量替换，可得到速度的闭式转换，其他参数化亦类似。总结为：

结论 6.3.1. 不论采用 *VE*、*VP*（例如三角调度）、*FM* 或 *RF* 等何种 (α_t,σ_t)，仿射插值都可经适当时间变量变换与标量缩放相互转换。

译注： 结论沿用原文概括，其作为真正可逆时间替换的解释仍受前述非零尺度、连续性和严格单调性限制；逐点状态恒等式本身不保证这些条件，也不保证离散算法相同。

四种参数化的训练目标。 设 $x_t=\alpha_t x_0+\sigma_t\epsilon$，$\sigma_t>0$，调度可微且 $\alpha_t'\sigma_t-\alpha_t\sigma_t'\neq 0$。理想目标为

$$\epsilon^*(x_t,t)=\mathbb{E}[\epsilon\mid x_t],\qquad x_0^*(x_t,t)=\mathbb{E}[x_0\mid x_t],$$
$$v^*(x_t,t)=\mathbb{E}[\alpha_t'x_0+\sigma_t'\epsilon\mid x_t].$$

由命题 6.3.1，

$$\nabla_{x_t}\log p_t(x_t)=-\frac{1}{\sigma_t}\epsilon^*(x_t,t)=\frac{\alpha_t}{\sigma_t^2}\left(x_0^*(x_t,t)-\frac{x_t}{\alpha_t}\right),$$
$$v^*=\alpha_t'x_0^*+\sigma_t'\epsilon^*.$$

采用输出头转换

$$s_\phi\equiv-\frac{1}{\sigma_t}\epsilon_\phi\equiv\frac{\alpha_t}{\sigma_t^2}\left(x_\phi-\frac{x_t}{\alpha_t}\right),$$

以及速度到得分的转换

$$s_\phi=\frac{\alpha_t}{\sigma_t(\alpha_t'\sigma_t-\alpha_t\sigma_t')}v_\phi-\frac{\alpha_t'}{\sigma_t(\alpha_t'\sigma_t-\alpha_t\sigma_t')}x_t,$$

逐样本平方损失仅相差时间权重：

$$\begin{aligned}\|s_\phi-\nabla_{x_t}\log p_t(x_t)\|_2^2&=\frac{1}{\sigma_t^2}\|\epsilon_\phi-\epsilon^*\|_2^2\\&=\frac{\alpha_t^2}{\sigma_t^4}\|x_\phi-x_0^*\|_2^2\\&=\left(\frac{\alpha_t}{\sigma_t(\alpha_t'\sigma_t-\alpha_t\sigma_t')}\right)^2\|v_\phi-v^*\|_2^2.\end{aligned}\tag{6.3.6}$$

译注： 式中各误差以边缘理想量为目标，是固定 x_t 的代数恒等式。实际条件训练误差含随机 x_0,ϵ，与这些误差在取总体期望后还相差与模型无关的条件方差常数。出现 x_t/α_t 时仍需 $\alpha_t\neq 0$，或先化简再讨论极限。

由命题 6.3.3，令 $c(t)=\alpha_t+\sigma_t$、$\tau(t)=\sigma_t/(\alpha_t+\sigma_t)$，任意仿射流可转到 $x_t=c(t)x^{\mathrm{FM}}_{\tau(t)}$。求导得到

$$v_\phi(x_t,t)=c'(t)x^{\mathrm{FM}}_{\tau(t)}+c(t)\tau'(t)v_\phi^{\mathrm{FM}}(x^{\mathrm{FM}}_{\tau(t)},\tau(t)),\qquad x^{\mathrm{FM}}_{\tau(t)}=\frac{x_t}{c(t)}.$$

v^* 也有同样关系，故速度损失变为

$$\|v_\phi(x_t,t)-v^*(x_t,t)\|_2^2=(c(t)\tau'(t))^2\times\left\|v_\phi^{\mathrm{FM}}\left(\frac{x_t}{c(t)},\tau(t)\right)-(v^{\mathrm{FM}})^*\left(\frac{x_t}{c(t)},\tau(t)\right)\right\|_2^2.$$

由此得到：

结论 6.3.2. 得分、噪声、干净样本与速度的训练目标在理论上等价，至多相差由 (α_t,σ_t) 决定的时间权重；速度还涉及含 x_t 的仿射输出头转换。

6.3.4 （可选）参数化与规范流的分析

前面表明四种参数化在数学上等价，可相互转换，正向仿射加噪也等价于规范形式 $x_t^{\mathrm{FM}} = (1-t)x_0 + t\epsilon$。本节进一步分析，速度预测与规范仿射流结合可能具有哪些优势。问题是：参数化和调度如何塑造模型所学及采样方式？从两个视角展开：

- **回归目标与调度**。为何速度预测与规范线性调度 $(\alpha_t, \sigma_t) = (1-t, t)$ 的结合自然：条件速度目标的尺度不随时间变化，速度分解中显式调度曲率项消失。
- **求解器含义**。这一参数化如何与数值积分相互作用；详细求解器分析留待第 9 章。

先区分两种速度。可计算训练目标是条件速度

$$v_t(x_t \mid z) = x_t' = \alpha_t' x_0 + \sigma_t' \epsilon, \qquad z = (x_0, \epsilon),$$

PF-ODE 推断中移动样本所用的是理想边缘速度

$$v^*(x,t) = \mathbb{E}[v_t(\cdot \mid z) \mid x_t = x].$$

视角 1：为何 $(\alpha_t, \sigma_t) = (1-t, t)$ 是自然调度。 记 $\sigma_t := \zeta(t)$、$\alpha_t := 1 - \zeta(t)$，则

$$v_t(x_t \mid z) = \zeta'(t)(\epsilon - x_0), \qquad z = (x_0, \epsilon).$$

单位尺度的回归目标。 规范调度 $\zeta(t) = t$ 下，

$$\begin{aligned} \mathbb{E}[\|v_t(\cdot \mid z)\|_2^2] &= \mathbb{E}_\epsilon \|\epsilon\|_2^2 + \mathbb{E}_{x_0} \|x_0\|_2^2 \\ &= D + \underbrace{\operatorname{Tr} \operatorname{Cov}[x_0]}_{\text{总方差}} + \underbrace{\|\mathbb{E} x_0\|_2^2}_{\text{均值}}. \end{aligned} \tag{6.3.7}$$

因此期望目标大小不随 t 变化。数据标准化为零均值、单位协方差（$\operatorname{Cov}[x_0] = I$）后，$\alpha_t' x_0$ 与 $\sigma_t' \epsilon$ 在所有时间贡献相当，避免端点附近梯度爆炸或消失。考虑训练目标

$$\mathcal{L}_{\text{velocity}}(\phi) = \mathbb{E}_t \mathbb{E}_{x_0, \epsilon} \|v_\phi(x_t, t) - v_t(x_t \mid z)\|_2^2.$$

链式法则给出参数梯度

$$\nabla_\phi \mathcal{L}_{\text{velocity}}(\phi) = 2\mathbb{E}_t \mathbb{E}_{x_0, \epsilon} \left[\partial_\phi v_\phi(x_t, t)^\top \big(v_\phi(x_t, t) - v_t(x_t \mid z) \big) \right].$$

故目标尺度 $\|v_t(x_t \mid z)\|_2$ 影响梯度稳定性：其他条件相同时，若它在某些时间坍缩到零或发散，梯度往往随之消失或爆炸。规范选择 $\zeta(t) = t$ 的式 (6.3.7) 不随时间变化，因此在 $\mathbb{E}\|\partial_\phi v_\phi(x_t, t)\|^2$ 及时间权重受控时，不存在由回归信号本身造成的 $t = 0, 1$ 端点坍缩或发散。[4]

[4]译注：此处恒定的是条件目标的期望平方模，不是每个样本的单位范数；式中使用标准高斯噪声与数据独立、噪声零均值及有限数据二阶矩。目标尺度恒定本身并非全部网络梯度稳定性的充分保证，上述叙述须连同原文所列 Jacobian 和权重条件理解。

规范调度与速度预测的相互作用。 一般仿射路径的理想速度分解为

$$v^*(x,t) = \alpha_t' x^*(x,t) + \sigma_t' \epsilon^*(x,t),$$
$$x^* = \mathbb{E}[x_0 \mid x_t = x], \qquad \epsilon^* = \mathbb{E}[\epsilon \mid x_t = x].$$

固定 x 对时间求导，

$$\partial_t v^* = \underbrace{\alpha_t'' x^* + \sigma_t'' \epsilon^*}_{\text{调度曲率}} + \alpha_t' \partial_t x^* + \sigma_t' \partial_t \epsilon^*.$$

线性调度 $\alpha_t = 1 - t, \sigma_t = t$ 使曲率项消失，$\alpha_t'' = \sigma_t'' = 0$，于是 v^* 的时间变化主要反映后验演化 $\partial_t x^*, \partial_t \epsilon^*$，而非调度。速度预测中这一效应尤其清楚：系数 α_t', σ_t' 为常数 $-1, +1$，漂移中没有额外时间缩放。得分、干净样本或噪声参数化则常引入 σ_t'/σ_t、α_t'/α_t 等比值，即使线性调度也可在端点急剧变化。因此，这一优势原则上虽非独有，线性调度与速度预测的结合仍使理想速度的时间依赖尤其稳定、透明。

最小化条件能量。 转向第 7 章的最优传输视角。条件动能量化沿正向路径条件速度的总期望运动，即从 x_0 到 ϵ 所需的瞬时运动或动能付出：

$$\begin{aligned}\mathcal{K}[\zeta] &:= \int_0^1 \mathbb{E}_{x_0,\epsilon}[\|v_t(\cdot \mid z)\|_2^2]\, dt \\ &= \left(D + \operatorname{Tr}\operatorname{Cov}[x_0] + \|\mathbb{E}x_0\|_2^2\right) \int_0^1 (\zeta'(t))^2\, dt.\end{aligned}$$

最小化 $\mathcal{K}[\zeta]$，就是在仿射插值族 $x_t = (1 - \zeta(t))x_0 + \zeta(t)\epsilon$ 中寻找期望意义下最平滑、能量最小的路径。边界 $\zeta(0) = 0, \zeta(1) = 1$ 下，Euler–Lagrange 方程 $\zeta''(t) = 0$ 给出极小化解 $\zeta(t) = t$，对应直的条件路径。因此，该族所有光滑调度中，规范流是从 x_0 移到 ϵ 最节能的方式；命题 7.5.1 将详细讨论。

理想边缘速度的能量。 线性调度总使上述条件速度能量最小，却未必使边缘理想速度 v^* 的能量最小。v^* 的大小可沿概率路径变化，最小能量调度因而可能用不同速度经过不同位置。具体令

$$y_u = (1 - u)x_0 + u\epsilon, \qquad u \in [0, 1],$$
$$b_u(y) := \mathbb{E}[\epsilon - x_0 \mid y_u = y], \qquad \kappa(u) := \mathbb{E}_{y_u}[\|b_u(y_u)\|_2^2].$$

u 为仿射概率路径的位置，$\kappa(u)$ 衡量沿路径单位位移所对应理想速度的期望平方模。调度 $u = \zeta(t)$ 指定通过速度。由 $x_t = y_{\zeta(t)}$，

$$v^*(x,t) = \zeta'(t) b_{\zeta(t)}(x),$$
$$\mathcal{K}_{\text{marg}}[\zeta] = \int_0^1 \kappa(\zeta(t))(\zeta'(t))^2\, dt.$$

假设 $\kappa(u) > 0$ 且有足够正则性，最小化得到

$$\kappa(\zeta(t))(\zeta'(t))^2 = \text{常数}, \qquad \zeta'(t) \propto \frac{1}{\sqrt{\kappa(\zeta(t))}}.$$

即理想速度期望大小越大的位置走得越慢，越小的位置越快。因此，只有 $\kappa(u)$ 沿路径恒定时，$\zeta(t) = t$ 才使边缘速度能量最小；这区别于条件速度结果，后者在线性调度下总是该仿射族的匀速最小能量选择。

视角 2：速度预测为何可视为自然的采样选择。 PF-ODE 采样最终需要速度场，因此直接预测 ODE 右端量尤其直接；干净、噪声及得分预测则通过当前状态和网络预测的组合编码同一理想速度。在理想层面，式 (6.3.2) 是同一 $v^*(x,t)$ 的精确转换，改变参数化并不改变基础理想 PF-ODE。这里关注采样中学得 PF-ODE 如何表示，训练损失仍可另外选择。

干净、噪声和得分预测下的 PF-ODE。 式 (6.3.2) 的前三式共有形式

$$\frac{dx(t)}{dt} = \underbrace{L(t)x(t)}_{\text{已知线性项}} + \underbrace{N_{\phi^\times}(x(t),t)}_{\text{依赖网络的项}}.$$

$L(t)$ 是调度决定的已知标量，$N_{\phi^\times}$ 含有乘在干净、噪声或得分预测上的相应时间系数。例如噪声预测下，

$$L(t) = \frac{\alpha_t'}{\alpha_t}, \qquad N_{\phi^\times}(x,t) = -\sigma_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\epsilon_{\phi^\times}(x,t).$$

这有利于数值积分：已知线性项可解析处理，网络项则数值近似。DPM-Solver（Lu et al., 2022b）等基于指数积分器的扩散求解器正是利用此结构，第 9 章将详细介绍。

速度预测下的 PF-ODE。 此时形式直接而简单：

$$\frac{dx(t)}{dt} = v_{\phi^\times}(x(t),t) \approx v^*(x(t),t).$$

单次网络评价直接给出标准 ODE 求解器需要的量，无需先与单独线性项组合。规范线性调度使联系尤其透明：对 $x_t = (1-t)x_0 + t\epsilon$，速度预测确定端点预测

$$\widehat{x}_0 = x_t - tv_{\phi^\times}(x_t,t), \qquad \widehat{\epsilon} = x_t + (1-t)v_{\phi^\times}(x_t,t).$$

用同一次预测从 t 移到 s，得到

$$(1-s)\widehat{x}_0 + s\widehat{\epsilon} = x_t + (s-t)v_{\phi^\times}(x_t,t),$$

恰好是规范线性调度下对学得速度场作普通 Euler 更新。因此速度预测与线性调度把模型预测同 PF-ODE 数值积分直接联系起来。更一般调度与求解器细节留待第 9 章。总之，速度预测直接提供所需速度，其余类型经调度相关变换表示同一理想动力学；这正是称速度预测对采样“自然”的主要意义。

小结。 速度预测结合规范线性调度有目标尺度恒定、无调度曲率等理论优点，但并不必然普遍更优。性能还依赖架构、归一化、时间权重、采样器与离散步数、引导强度、正则化、数据缩放和总体训练预算。不同数据和目标可能更适合其他参数化或调度；最优配置最终应通过验证和消融实验决定。

6.4 共同基础：Fokker–Planck 方程

本节说明，变分、得分与流三种视角不是互不相干的构造，而来自同一统一原理：给定正向过程下支配密度演化的连续性（Fokker–Planck）方程。

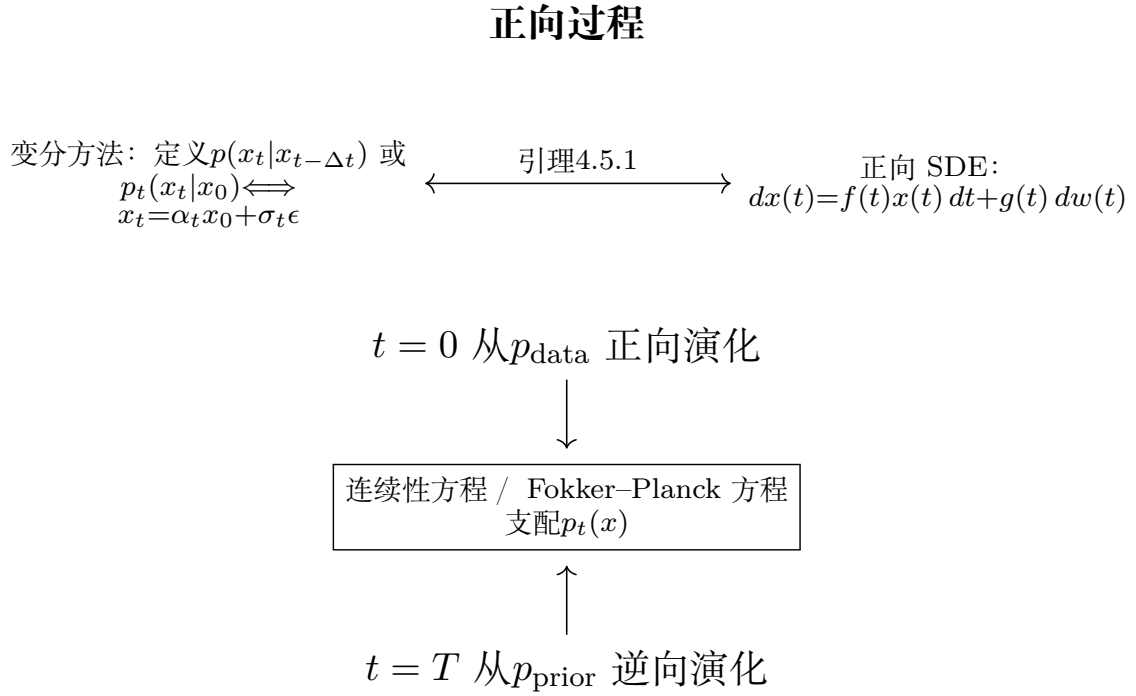


图 6.2: 变分、SDE 与 ODE 表述通过连续性方程联系的统一视角：所有 $p_t(x)$ 遵循共同密度演化。速度 $v^*(x,t) = f(t)x - \frac{1}{2}g^2(t)s^*(x,t)$ 由得分 $s^*(x,t) := \nabla_x \log p_t(x)$ 支配。f, g, σ_t, α_t 为预定时间函数，$\gamma(t)$ 是可调时间超参数。来源：作者绘制；按源物理 208 页重建可编辑数学箭头图。

先回顾第 4.6 节：离散核与 Bayes 公式的变分视角，同连续动力学的得分 SDE 视角，可通过变分模型是基础正/逆 SDE 的一致离散化这一点联系起来。逐步经离散核算得的边缘密度，以与连续动力学 Fokker–Planck 方程相容的方式演化，说明两者基本等价。随后，第 6.4.1 节联系流与得分视角：ODE 确定的密度路径，其边缘也可由一族随机过程实现，于是确定性流和随机 SDE 处于同一家族。三种视角统一在图 6.2 的框架下，第 6.5 节作结。[5]

6.4.1 流方法与得分 SDE 的联系

扩散模型的一个显著特点，是确定性或随机动力系统都能描绘同一概率分布演化。本节联系第 5.2 节 ODE 流与得分 SDE：定义生成 ODE 的速度场可变为遵循同一 Fokker–Planck 动力学的随机对应，提供确定性插值与随机采样之间有原则的桥梁。从 ODE 到 SDE 的连续模型族，因而可生成同一数据分布路径。

考虑连续时间扰动核

$$p_t(x_t \mid x_0) = \mathcal{N}(x_t; \alpha_t x_0, \sigma_t^2 I), \qquad x_0 \sim p_{\text{data}}.$$

它诱导边缘路径 $p_t(x_t) = \mathbb{E}_{x_0 \sim p_{\text{data}}}[p(x_t \mid x_0)]$，且 $p_T \approx p_{\text{prior}}$。为匹配此路径，考虑

$$\frac{dx(t)}{dt} = v_t(x(t)), \qquad t \in [0, T], \tag{6.4.1}$$

其中 $v_t(x) = \mathbb{E}[\alpha_t' x_0 + \sigma_t' \epsilon \mid x]$ 是式 (5.2.9) 的理想速度（时间已翻转，以遵从扩散模型约定）。从 $x(T) \sim p_{\text{prior}}$ 逆向积分便得到 p_0 的样本。[6]

这一 ODE 足以产生高质量样本，但加入随机性可能改善样本多样性，于是提出：

问题 6.4.1. *是否存在一个从 p_{prior} 出发的 SDE，使其边缘密度与式 (6.4.1) 相同？*

回答是：存在一族与相应 PF-ODE 产生同一边缘路径的逆时间 SDE。它们对该路径满足同一 Fokker–Planck 方程，因此单时间边缘与指定插值 $\{p_t\}_{t\in[0,T]}$ 一致。[7]

命题 6.4.1 (逆时间 SDE 与插值产生相同边缘)**.** *设 $\gamma(t) \geq 0$ 为任意时间系数。考虑以原时间变量 t 写出、从 T 逆向积分到 0 的 SDE:*

$$\begin{aligned} d\overline{x}(t) = &\left[v^*(\overline{x}(t), t) - \frac{1}{2}\gamma^2(t) s^*(\overline{x}(t), t) \right] dt \\ &+ \gamma(t)\, d\overline{w}(t), \qquad t : T \to 0. \end{aligned} \tag{6.4.2}$$

[5]译注：第 4.6 节源文自身将推导限定为启发式。这里“一致离散化”及相同密度演化的概括，应在步长趋零、相应正则性和极限存在等条件下理解，不表示任意有限步变分方案与连续 SDE 逐路径或逐步精确相同。

[6]译注：若仅有 $p_T \approx p_{\text{prior}}$，从后者出发一般只能近似恢复 p_0；下述精确边缘命题明确以终端分布恰为 p_T 为条件。

[7]原注：为完整起见，正向 SDE 表示（此处不用）是

$$dx(t) = f(t)x(t)\, dt + g(t)\, dw(t),$$

f, g 与 (α_t, σ_t) 的关系由式 (4.5.2) 给出。

终端条件为 $\overline{x}(T) \sim p_T$。则过程 $\{\overline{x}(t)\}_{t\in[0,T]}$ 匹配 *ODE* 密度路径诱导的指定边缘 $\{p_t\}_{t\in[0,T]}$。得分 $s^*(x,t) := \nabla_x \log p_t(x)$ 与速度场满足

$$\begin{aligned} v^*(x,t) &= f(t)x - \frac{1}{2}g^2(t)s^*(x,t), \\ s^*(x,t) &= \frac{1}{\sigma_t}\frac{\alpha_t v^*(x,t) - \alpha_t' x}{\alpha_t'\sigma_t - \alpha_t\sigma_t'}. \end{aligned} \tag{6.4.3}$$

证明. 过程逆向积分、仍以原变量 t 求导时，逆时间 Fokker–Planck 方程为

$$\partial_t p_t = -\nabla\cdot\left(\left[v^* - \frac{1}{2}\gamma^2 s^*\right]p_t\right) - \frac{1}{2}\gamma^2\Delta p_t.$$

由 $s^* = \nabla\log p_t$，有 $\nabla\cdot(s^* p_t) = \Delta p_t$，二阶项抵消，得到

$$\partial_t p_t = -\nabla\cdot(v^* p_t),$$

即 PF-ODE 对应的一阶连续性方程。因此逆时间 SDE 和 ODE 诱导同一边缘密度路径。参见 Ma et al. (2024) 附录 A.2–A.3。 □

译注：密度层面的抵消是上述形式计算的关键；精确结论还需正密度/得分的适当正则性、SDE 存在且无爆破及相应密度方程的唯一性等条件。“任意 γ” 限于可定义相关过程的系数。逆时间 Wiener 过程应按适当逆滤过理解，不能只把正向路径改名。由速度恢复得分还需式 (6.4.3) 分母非零。近似学得模型一般不满足精确抵消，不能自动继承所有 γ 相同边缘的保证。

在命题 6.4.1 的理想层面，γ 可任取而不改变指定边缘：依赖它的漂移与扩散在 Fokker–Planck 方程中精确抵消。代表性选择有：

- $\gamma(t) = 0$ 恢复式 (6.4.1) 的 ODE；
- $\gamma(t) = g(t)$ 时，式 (6.4.2) 成为式 (4.1.6) 的逆时间 SDE，因为命题 6.3.1 给出 $v^*(x,t) = f(t)x - \frac{1}{2}g^2(t)s^*(x,t)$；
- 还有其他选择。例如 Ma et al. (2024) 选择 $\gamma(t)$，最小化从 $t = T$ 求解式 (6.4.2) 后的 $t = 0$ 密度与 p_{data} 之间的 KL 间隙。

按得分 SDE 的方式，可用式 (6.4.3) 将训练后的速度 $v_{\phi^\times}(x,t)$ 转为得分 $s_{\phi^\times}(x,t)$，代入式 (6.4.2) 定义经验逆时间 SDE，再从 $\overline{x}(T) \sim p_{\text{prior}}$ 数值逆向积分。

该命题展示扩散模型的灵活性：正向过程诱导边缘路径后，可由包括 PF-ODE 及

$$d\overline{x}(t) = \left[v^*(\overline{x},t) - \frac{1}{2}\gamma^2(t)s^*(\overline{x},t)\right]dt + \gamma(t)\,d\overline{w}(t), \qquad \gamma(t)\geq 0$$

在内的一整族逆时间动力学从 T 到 0 实现。γ 改变个体轨迹的随机运动，却使指定路径上的 Fokker–Planck 方程都化为同一密度方程

$$\partial_t p_t = -\nabla_x\cdot\big(v^*(x,t)p_t(x)\big).$$

因为 $s^* = \nabla_x\log p_t$，额外漂移与扩散在密度层面相消。因此 γ 在保持理想单时间边缘的同时控制轨迹随机性，把确定性 PF-ODE 与一族随机 SDE 联系起来，见图 6.2。

6.5 结束语

本章作为理论探索的拱心石，把变分、得分与流视角综合为连贯框架，说明它们不只是并行方法，而有深刻基本联系。

统一建立在两个核心洞见上。第一是各框架共同的条件化技巧：把难计算边缘训练目标变为可计算条件目标，使学习稳定高效。第二是支配密度演化的共同规则 Fokker–Planck 方程：三种视角以各自方式构造遵守此动力学的生成过程。

噪声、干净数据、得分和速度理想预测还包含相同信息，可代数转换。这不意味着预测参数化只是外观差异：有限容量网络可用不同方式近似这些目标，训练目标可赋予不同噪声水平不同误差权重，有限步求解器也可随近似动力学的表示而表现不同。应区分基础连续理论等价与实际训练或采样算法等价。但密度层面的原理不变：现代扩散方法构造沿指定概率路径、使边缘从简单先验输运向数据分布的动力学。

有了这一统一基础，可以从基础理论走向实际应用及加速。生成等价于求解微分方程的洞见，为控制和优化提供了有力平台。后续各部将利用这一理解处理实践挑战：

1. C 部关注推断时改进采样：如何引导生成轨迹、实现可控生成（第 8 章），以及用高级数值求解器大幅加速缓慢迭代采样（第 9 章）。

2. D 部超越迭代求解器，直接学习快速生成器：研究经教师蒸馏（第 10 章）或从头训练（第 11 章），用一步或少数几步产生高质量样本的方法。

统一了扩散模型 “是什么” 和 “为什么” 之后，下面转向令人振奋而实际的 “如何做”。

第七章　（可选）扩散模型与最优传输

把一个分布映射为另一个分布（生成是其中的特例）是一项核心挑战。流匹配通过学习随时间变化的速度场，将质量从源输运到目标，自然联系到传输理论：经典最优传输寻找分布间代价最小的路径，其熵正则形式——Schrödinger 桥——则相对于 Brownian 运动等参考过程，选择最可能的受控扩散。

本章回顾最优传输、熵正则最优传输与 Schrödinger 桥的基础，把它们作为分布到分布问题的不同表述。由此提出核心问题：扩散模型在何种程度上实现这些最优传输？扩散模型有两种视角：由正/逆 SDE 定义的随机过程，以及由 PF-ODE 给出的确定性过程。随机视角直接联系熵正则最优传输，而 PF-ODE 一般不对应任何已知传输目标。由此留下开放问题：什么条件下可把扩散模型看作在求解最优传输问题？

学完本章后，你将能够：

- 区分传输耦合、确定性传输映射、动态传输流与随机 Schrödinger 桥，并在概念上联系深度生成建模；
- 理解经典 OT、熵正则 OT 与 Schrödinger 桥问题分别优化什么，及其相互关系；
- 说明标准扩散正/逆 SDE 一般为何不求解指定两端点的 Schrödinger 桥问题；
- 说明扩散 PF-ODE 为何定义确定性传输映射，却一般不等于二次代价最优传输映射。

阅读路线。　本章对扩散模型主线是可选内容。若想精确回答“扩散在何种意义下（如果存在这种意义）是最优传输？”，可阅读本章。

7.1　分布到分布转换的序幕

扩散模型将终端分布固定为标准高斯 p_{prior}，但很多应用需要分布到分布转换：把源分布 p_{src} 变为另一目标 p_{tgt}，如把草图变为照片般逼真的图像，或转换艺术风格。

现代扩散方法提供了实用途径。SDEdit（Meng et al., 2021b）等单端点方法从 $t = 0$ 的源图像出发，扩散至中间时间 t，再用目标域上预训练的扩散模型逆转过程，产生与目标分布风格和内容相匹配的输出。

Dual Diffusion Bridge（Su et al., 2022）等双端点方法则经共享潜分布连接两域，通常该潜分布为 $t = 1$ 的高斯。正向概率流 ODE 把 p_{src} 样本输运到潜空间，目标域训练的逆 ODE 再映射至 p_{tgt}。除这些采样时方法外，第 5.2 节的流匹配提供训练式替代：直接学习从 p_{src} 连续移动质量到 p_{tgt} 的 ODE 流。

关键在于，分布间转换不止需要两个单独训练的模型，还需要有原则地匹配两端动力学、并以“最便宜”（代价高效）的方式实现映射。本节不综述众多扩散转换应用，而转向这一经典问题的数学基础，重点讨论最优传输（OT）及其熵变体 Schrödinger 桥（SB）。理论界长期将其作为数学意义下代价高效的分布变换的规范表述。根本问题是：

问题 7.1.1. *给定两个概率分布，如何在使总代价最小的同时，最高效地将一个变为另一个？*

代价 $c(x,y)$ 是把单位质量从点 x 移到点 y 所赋予的非负惩罚，常用平方距离 $c(x,y)=\|x-y\|^2$。本节简要说明扩散及流匹配如何联系经典与正则最优传输，中心问题是：

问题 7.1.2. *扩散模型是否是连接 p_{data} 与 p_{prior} 的某种最优传输？如果是，又在何种意义下？*

第 7.2 节先明确“最优性”：回顾经典 OT 的静态 Monge–Kantorovich 形式（式 (7.2.1)）、动态 Benamou–Brenier 形式（式 (7.2.3)，在连续性方程约束下最小化动能），及式 (7.2.5) 的熵正则 OT，后者等价于式 (7.2.8) 的 SB 问题。动态 OT 诱导满足连续性方程的确定性流，SB 则诱导边缘依 Fokker–Planck 方程演化的受控扩散。第 7.3 节给出这些表述间的高层对应。

随后分两部分讨论。第 7.4 节说明，标准扩散中固定的正向加噪 SDE 本身不是任意 $p_{\text{src}},p_{\text{tgt}}$ 间的 Schrödinger 桥：正向过程是选定参考扩散，正向时间和逆时间 SDE 一般都不强制精确匹配指定目标端点。因此，除非明确求解这两个端点的 SB 问题，它并非熵正则 OT 的最优解；不过，由于锚定一个起点，它是半桥问题的最优解。

第 7.5 节再回到生成设定 $p_{\text{src}}=p_{\text{prior}}$（高斯）、$p_{\text{tgt}}=p_{\text{data}}$。PF-ODE 按构造定义输运先验到数据的确定性映射，但一般不是指定代价（如二次 W_2）的 OT 映射：它实现许多可行确定性耦合中的一个，并不最小化 Benamou–Brenier 作用量。随后讨论原第 5.4.1 节的“整流流”过程能否导向 OT 映射，一般也无此理论保证。因此，精确刻画扩散 PF-ODE 映射与 OT 的关系仍是困难的未解问题。[1]

7.2 问题设定的分类

本节介绍将质量从 p_{src} 输运到 p_{tgt} 的“最高效”或“最优”方式，包括经典 OT 及其熵正则变体，后者有称为 Schrödinger 桥的等价表述。这些分类为后文理解扩散模型提供背景。

7.2.1 最优传输（OT）

OT 的 Monge–Kantorovich 静态表述。 固定代价 $c:\mathbb{R}^D\times\mathbb{R}^D\to\mathbb{R}$，指定把概率质量从 x 送到 y 的费用，目标是尽可能便宜地把源分布变为目标分布。

定义代价前须知道配对的 (x,y)。这一角色由耦合承担：它是 $\mathbb{R}^D\times\mathbb{R}^D$ 上边缘为 $p_{\text{src}},p_{\text{tgt}}$ 的联合分布 γ。抽取 $(x,y)\sim\gamma$，就将源点 x 与目标点 y 匹配。若 γ 对 Lebesgue 测度有密度 $\gamma(x,y)$，边缘约束为

$$\int_{\mathbb{R}^D}\gamma(x,y)\,dy=p_{\text{src}}(x),\qquad\qquad\int_{\mathbb{R}^D}\gamma(x,y)\,dx=p_{\text{tgt}}(y).$$

积分消去 y 恢复 x 上源密度，消去 x 则恢复 y 上目标密度。两个标准例子是：

[1]译注：此处保留原文问题导向的概括。精确从先验恢复数据仍以前章所述精确终端匹配、理想场及精确积分为条件；标准加噪在有限终时一般仅近似高斯。半桥最优性及“未解”的具体范围以下文定义和冻结版本写作时点为准。原文此处定位第 5.4.1 节；Reflow 迭代的对应说明见本译稿第 5.4.2 节。

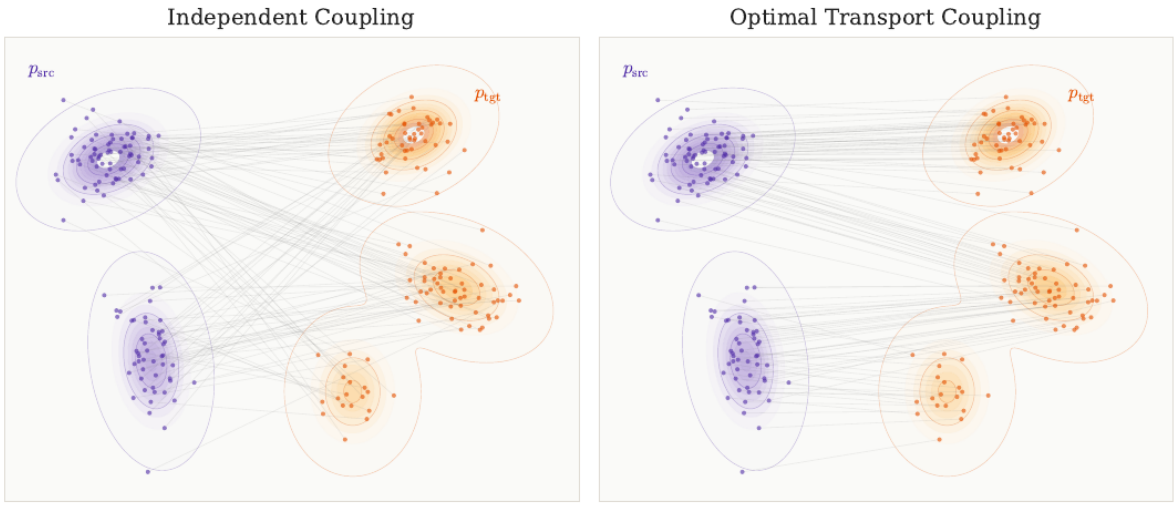


图 7.1: 二维中相同 $p_{\text{src}}, p_{\text{tgt}}$ 间的两种耦合。左：独立（随机）配对产生交叉路径，代价较高；右：最优耦合匹配相近质量，避免交叉。来源：作者借助 AI 辅助编程绘制；取自源物理 218 页。图内左、右标题分别为独立耦合与最优传输耦合。

1. **离散支撑**。有限点支撑时，耦合是非负矩阵 (γ_{ij})，行和为 $p_{\text{src}}(i)$，列和为 $p_{\text{tgt}}(j)$；γ_{ij} 是从 i 送到 j 的质量。

2. **确定性映射**。若存在可测映射 T 满足 $T_{\#}p_{\text{src}} = p_{\text{tgt}}$，则 $\gamma = (I, T)_{\#}p_{\text{src}}$ 是将每个 x 直接移到 $T(x)$ 的确定性耦合。

固定耦合后，传输代价即该方案下单位代价的平均：

$$\int c(x,y)\, d\gamma(x,y) = \mathbb{E}_{(x,y)\sim\gamma}[c(x,y)].$$

离散情形为 $\sum_{i,j} c_{ij}\gamma_{ij}$，连续情形为二重积分。以下主要关注连续情形。最优传输从可行耦合中选择期望代价最小者：

$$\mathrm{OT}(p_{\text{src}}, p_{\text{tgt}}) := \inf_{\gamma\in\Gamma(p_{\text{src}},p_{\text{tgt}})} \int c(x,y)\, d\gamma(x,y). \tag{7.2.1}$$

可行集只施加边缘或质量守恒约束：

$$\Gamma(p_{\text{src}}, p_{\text{tgt}}) = \Big\{\gamma \in \mathcal{P}(\mathbb{R}^D \times \mathbb{R}^D) : \int \gamma(x,y)\, dy = p_{\text{src}}(x), \quad \int \gamma(x,y)\, dx = p_{\text{tgt}}(y)\Big\},$$

$\mathcal{P}$ 表示概率测度集合。[2]

特例：Wasserstein-2 距离。 取二次代价 $c(x,y) = \|x-y\|^2$，得到

$$W_2^2(p_{\text{src}}, p_{\text{tgt}}) := \inf_{\gamma\in\Gamma(p_{\text{src}},p_{\text{tgt}})} \mathbb{E}_{(x,y)\sim\gamma}[\|x-y\|^2].$$

[2]译注：源文以密度积分写可行集，但集合本身包括一般概率测度，特别确定性耦合常对乘积 Lebesgue 测度奇异。一般情形应把约束理解为两个坐标投影的推前边缘，不能因不存在联合密度而排除这些耦合。

在源、目标的适当假设下，Brenier 定理（见定理 7.1）[3]保证最优耦合集于某个确定性映射 $T:\mathbb{R}^D\to\mathbb{R}^D$ 的图像，故可等价写成[4]

$$W_2^2(p_{\mathrm{src}},p_{\mathrm{tgt}})=\inf_{\substack{T:\mathbb{R}^D\to\mathbb{R}^D\\ T_{\#}p_{\mathrm{src}}=p_{\mathrm{tgt}}}}\mathbb{E}_{x\sim p_{\mathrm{src}}}[\|T(x)-x\|^2]. \tag{7.2.2}$$

推前约束意为 $x\sim p_{\mathrm{src}}$ 时 $T(x)\sim p_{\mathrm{tgt}}$。因此，Wasserstein-2 距离表示匹配指定边缘的耦合或映射中最小期望平方传输代价；最优映射 $T^*(x)$ 称为 Monge 映射。**译注：**严格按上式，最小平方代价是 W_2^2，距离 W_2 还需开平方；正文的距离措辞按源保留。Brenier 结论还应连同后文有限二阶矩等假设理解，唯一性按源分布几乎处处计。

OT 的 Benamou–Brenier 动态表述。 除了静态直接映射，还可用连续流描述：

$$p_0:=p_{\mathrm{src}}\ \longrightarrow\ p_t\ \longrightarrow\ p_1:=p_{\mathrm{tgt}},\qquad t\in[0,1].$$

Benamou and Brenier (2000) 寻找描述质量随时间演化的光滑速度场 $v_t(x)$。对二次代价 $\|x-y\|_2^2$（即 W_2 距离），其动态形式[5]表明静态式 (7.2.1) 的最优值等于动能最小化值：

$$W_2^2(p_{\mathrm{src}},p_{\mathrm{tgt}})=\min_{\substack{(p_t,v_t):\ \partial_t p_t+\nabla\cdot(p_t v_t)=0\\ p_0=p_{\mathrm{src}},\ p_1=p_{\mathrm{tgt}}}}\int_0^1\int_{\mathbb{R}^D}\|v_t(x)\|^2 p_t(x)\,dx\,dt. \tag{7.2.3}$$

每个 t 的 p_t 都是 $\mathbb{R}^D$ 上的概率分布。特别地，最优流遵循 McCann 位移插值

$$T_t^*(x)=(1-t)x+tT^*(x),\qquad\qquad p_t=(T_t^*)_{\#}p_{\mathrm{src}},$$

其中 T^* 把源输运至目标；线性插值使质量沿直线匀速运动。最优映射还满足 Monge–Ampère 方程

$$p_{\mathrm{tgt}}(\nabla\psi(x))\det(\nabla^2\psi(x))=p_{\mathrm{src}}(x), \tag{7.2.4}$$

Brenier 定理给出 $T^*(x)=\nabla\psi(x)$、ψ 凸。但这一非线性 PDE 通常难以显式求解。它正是归一化流式 (5.0.1) 的变量替换关系；流参数化可逆映射、使 Jacobian 行列式易算，却一般不强制凸势梯度结构，因此训练后的流可明显不同于 Brenier/OT 映射。**译注：**点态经典 Monge–Ampère 式还需要相应密度和势的正则性；一般 Brenier 映射应以几乎处处或弱意义理解，不能单凭存在凸势便假定处处二阶光滑。

7.2.2 熵正则最优传输（EOT）

以样本经验分布说明动机。设源支撑于 $\{x^{(i)}\}_{i=1}^n\subset\mathbb{R}^D$、权重为 a_i，目标支撑于 $\{y^{(j)}\}_{j=1}^n\subset\mathbb{R}^D$、权重为 b_j。耦合是行和为 a、列和为 b 的非负 $n\times n$ 矩阵 γ；γ_{ij} 是从 $x^{(i)}$ 送到 $y^{(j)}$ 的质量。[6]

[3]原注：Brenier 定理讨论二次代价最优映射的存在与结构。特别地，若 p_{src} 不赋质量给维数至多 $D-1$ 的集合，最优映射 T^* 唯一存在。

[4]原注：W_2 常用三种表述：基于映射的 Monge 形式、基于耦合的 Kantorovich 形式，以及式 (7.2.3) 的 Benamou–Brenier 动态形式；在适当正则条件下三者等价。

[5]原注：Benamou–Brenier 形式通过在连续测度和速度路径上最小化动能，计算 W_2 距离。

[6]原注：经验离散测度是连续分布的有原则近似。若底层代价为 $c(x,y)=d(x,y)^p$（OT 值为 W_p^p），且测度有有限 p 阶矩，经验测度在 W_p 下依定量速率收敛到总体；见 Fournier and Guillin (2015) 及 Peyré, Cuturi, et al. (2019) 的综述。

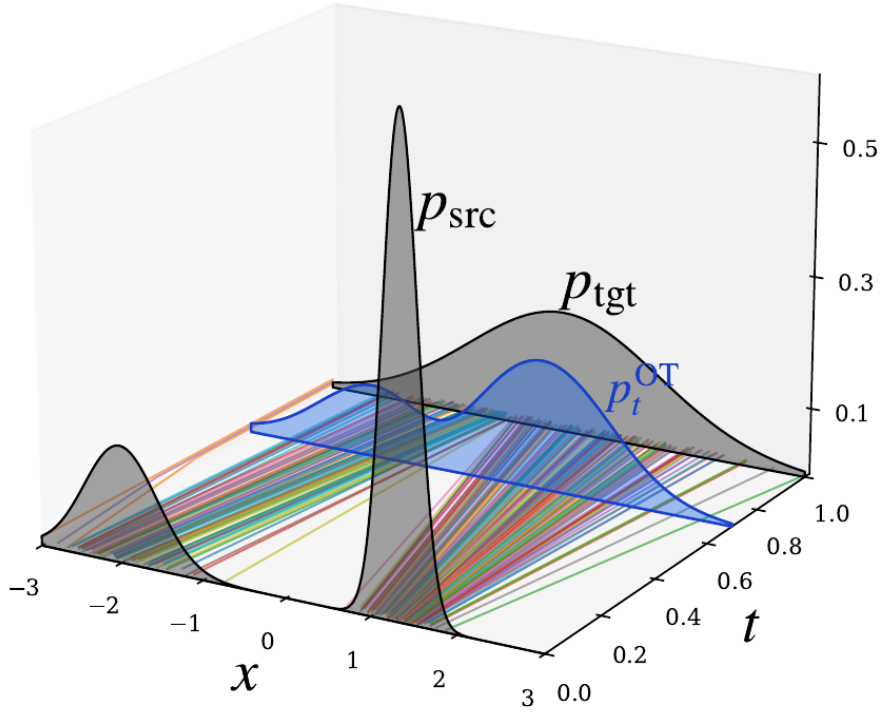


图 7.2: OT 的动态视角。插值 p_t^{OT} 随时间连续演化，给出把源确定性映射至目标的最低代价方案，即 McCann 位移插值。图中 x 为状态、t 为时间。来源：作者绘制；取自源物理 221 页。

为何正则化 OT？ 此离散情形下（在式 (7.2.1) 中取计数测度），经典 OT 是对可行耦合最小化

$$\min_{\gamma=(\gamma_{ij})} \sum_{i,j} C_{ij}\gamma_{ij}, \qquad C_{ij} = c(x^{(i)}, y^{(j)}),$$

底层代价 $c : \mathbb{R}^D \times \mathbb{R}^D \to \mathbb{R}_{\geq 0}$ 已指定，如平方距离。主要有两个困难：

1. **非唯一与不稳定**。最优解 γ^* 未必唯一。两方案同样最优时，求解器可任选；样本位置、权重或代价等输入 (a, b, C) 的小变化，可导致解突然跳变。

2. **计算昂贵**。线性规划有 n^2 个变量、$2n$ 个约束。原文列举 Hungarian 算法（原引用键 `kuhn1955hungarian; munkres1957algorithms`）及网络单纯形法（Peyré, Cuturi, et al., 2019），称实际求解通常按 $O(n^3)$ 缩放，大 n 时难以承担。

为克服这些瓶颈，EOT 引入由 $\varepsilon > 0$ 控制的正则项：

$$\text{EOT}_\varepsilon(p_{\text{src}}, p_{\text{tgt}}) := \min_{\gamma \in \Gamma(p_{\text{src}}, p_{\text{tgt}})} \left\{ \int c(x, y)\, d\gamma(x, y) + \varepsilon D_{\text{KL}}(\gamma \| M) \right\}. \tag{7.2.5}$$

参考测度 M 通常取边缘乘积 $p_{\text{src}} \otimes p_{\text{tgt}}$。KL 项直接联系传输方案的 Shannon 熵：

$$D_{\text{KL}}(\gamma \| p_{\text{src}} \otimes p_{\text{tgt}}) = -H(\gamma) + \text{常数},$$
$$H(\gamma) := -\int \gamma(x, y) \log \gamma(x, y)\, dx\, dy.$$

译注： Hungarian 算法直接适用于相应指派问题，不是任意带权传输线性规划的通用同一复杂度证明；源文的缩放为算法概述。连续情形的熵分解要求相应密度、绝对连续性和熵项有意义，不能用无穷项相减；离散熵按求和解释。

熵正则为何有帮助？

1. **质量铺展**。$t \mapsto t\log t$ 凸且在大 t 时增长快，最小化 $\int \gamma\log\gamma$ 惩罚尖锐耦合；固定 $\int\gamma = 1$ 时偏好质量在 (x, y) 上更均匀。等价地，最大化熵促进更高的“不确定性”或弥散性。

2. **严格凸与唯一**。H 严格凹，故式 (7.2.5) 对 γ 严格凸，给出随 $(p_{\text{src}}, p_{\text{tgt}}, c)$ 连续变化的唯一极小化解 γ^*_ε。

3. **Sinkhorn 形式与正性**。温和条件下[7]，最优解具有 Schrödinger/Sinkhorn 形式

$$\gamma^*_\varepsilon(x, y) = u(x)\exp\left(-\frac{c(x, y)}{\varepsilon}\right)v(y)p_{\text{src}}(x)p_{\text{tgt}}(y),$$

   其中 u, v 为正缩放函数，至多相差一个全局因子。实践中用有限样本近似连续式，化为有限 Sinkhorn 迭代。熵目标严格凸，缩放算法（Sinkhorn/IPFP）可高效求解（Sinkhorn, 1964; Cuturi, 2013）。每个边缘有 n 个支撑点的稠密 $n\times n$ 核，每次迭代耗时与内存均为 $O(n^2)$，因而更易扩展（Altschuler et al., 2017）。

4. ε **极限**。当 $\varepsilon\to 0$，γ^*_ε 逐渐集中，趋向可能奇异的经典 OT 耦合（第 7.3.2 节将重访）；ε 增大时则逐渐铺展，趋向独立耦合 $p_{\text{src}}\otimes p_{\text{tgt}}$。

译注： 严格凸保证至多一个极小化解，存在性、连续依赖及极限收敛仍需相应可积/紧性/代价与拓扑条件；每步 $O(n^2)$ 不等于总复杂度与精度、正则强度无关。缩放唯一性通常指 $u\mapsto au, v\mapsto a^{-1}v$ 的配对不定性。原概括按这些适用条件理解。

7.2.3 Schrödinger 桥（SB）

SB 的 KL 表述。 Erwin Schrödinger 在 20 世纪 30 年代提出：粒子依 Brownian 运动等简单参考动力学运动，现观测到 $t = 0$ 分布为 p_{src}、$t = 1$ 分布为 p_{tgt}。在所有连接这两个分布的随机过程中，哪个最少偏离参考动力学？用 KL 衡量偏离，解就是将 Brownian 运动变形成满足边界条件过程的最可能方式。

令 $x_{0:T} := \{x_t\}_{t\in[0,T]}$ 为完整轨迹，P 为轨迹律，即整条样本路径的分布；其时间 t 边缘记为 p_t 或 P_t，描述单时间状态分布。对可测集 $A\subseteq\mathbb{R}^D$，

$$p_t(A) = P(x_t\in A).$$

直观上，从 P 抽许多完整轨迹、收集它们在时间 t 的状态，就可用经验分布表示 p_t；一维时可画直方图。

参考扩散满足

$$dx_t = f(x_t, t)\,dt + g(t)\,dw_t, \tag{7.2.6}$$

[7]原注：假设 $c < \infty$ 在 $p_{\text{src}}\otimes p_{\text{tgt}}$ 几乎处处成立，边缘核积分有限且为正。为简化，集中讨论 $\gamma^*_\varepsilon, p_{\text{src}}, p_{\text{tgt}}$ 对 Lebesgue 测度有密度的情况。

其中 $f : \mathbb{R}^D \times [0,T] \to \mathbb{R}^D$、$g : [0,T] \to \mathbb{R}$，$w_t$ 为标准 Brownian 运动。令 R 为完整轨迹的路径律、R_0 为初始边缘。SB 寻找与 R 的 KL 最接近、又匹配指定两端边缘的轨迹律：

$$\mathrm{SB}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_P D_{\mathrm{KL}}(P\|R), \qquad P_0 = p_{\mathrm{src}}, \quad P_T = p_{\mathrm{tgt}}. \tag{7.2.7}$$

最优 P^* 取决于所选参考 R。

SB 的随机控制视角。 不直接优化任意路径分布，而以参考动力学为锚，加入时间相关漂移 $v_t(x_t)$ 产生候选轨迹律：

$$dx_t = [f(x_t,t) + v_t(x_t)]\,dt + g(t)\,dw_t.$$

$v_t : \mathbb{R}^D \to \mathbb{R}^D$ 是式 (7.2.8) 待优化的控制漂移。标准可积条件（如 Novikov 条件）下，由 Girsanov 定理（附录 C.2.1），

$$\begin{aligned} D_{\mathrm{KL}}(P\|R) &= D_{\mathrm{KL}}(p_{\mathrm{src}}\|R_0) + \mathbb{E}_P\left[\int_0^T \frac{1}{2}\frac{\|v_t(x_t)\|^2}{g^2(t)}\,dt\right] \\ &= D_{\mathrm{KL}}(p_{\mathrm{src}}\|R_0) + \frac{1}{2}\int_0^T \int_{\mathbb{R}^D} \frac{\|v_t(x)\|^2}{g^2(t)} p_t(x)\,dx\,dt. \end{aligned}$$

p_t 为受控过程边缘，第二式来自全期望公式。SB 固定 $P_0 = p_{\mathrm{src}}$，第一项对控制为常数，可从优化中删去；$R_0 = p_{\mathrm{src}}$ 时它为零。因此可在把过程从 p_{src} 引向 p_{tgt} 的可行漂移中，最小化期

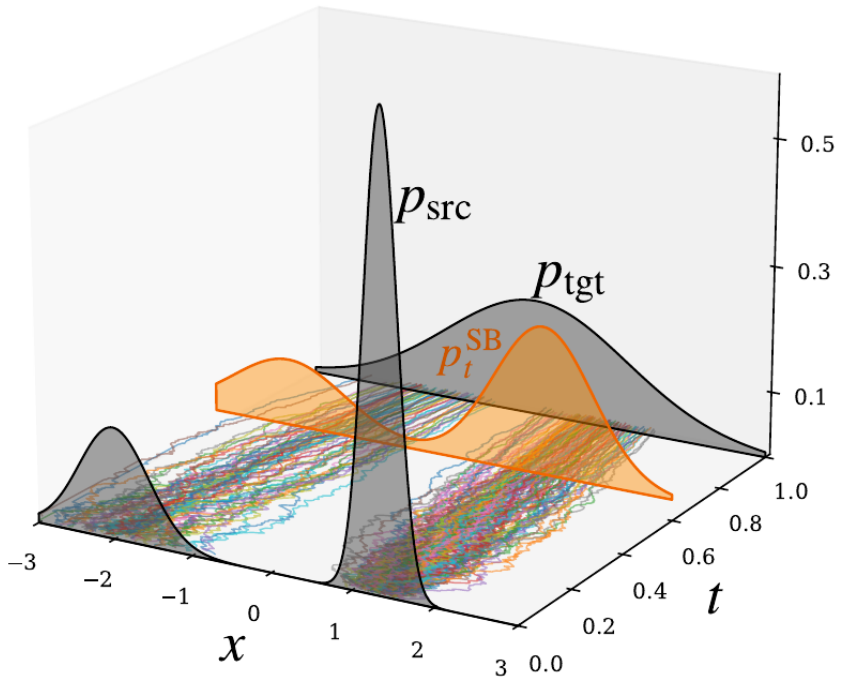


图 7.3: SB 的随机控制视角：在连接源、目标的同时，寻找最少偏离参考的随机路径；p_t^{SB} 为中间桥边缘。来源：作者绘制；取自源物理 225 页。

望控制能量（Dai Pra, 1991; Pra and Pavon, 1990; Pavon and Wakolbinger, 1991; Chen et al.,

2016）。初始边缘固定，可令参考过程 $R_0 = p_{\mathrm{src}}$ 而不改变最优控制，使初始 KL 为零，得到

$$\mathrm{SB}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \min_{\substack{v_t:\ dx_t=[f(x_t,t)+v_t(x_t)]dt+g(t)dw_t \\ x_0\sim p_{\mathrm{src}},\ x_T\sim p_{\mathrm{tgt}}}} \frac{1}{2}\int_0^T \int_{\mathbb{R}^D} \frac{\|v_t(x)\|^2}{g^2(t)} p_t(x)\,dx\,dt. \tag{7.2.8}$$

两端分布可任取；控制专为在它们之间 “架桥”，同时在 KL 意义下尽量靠近参考过程。**译注：** 本节 $f(x,t)$ 是一般参考漂移，v_t 是附加控制，并非此前章节无条件边缘速度的同一记号含义。除原文可积条件外，除以 g^2 及路径绝对连续性也须有定义；改变参考初始边缘时保持参考条件动力学，优化器不变但原最优值可差初始 KL 常数。

特殊 Brownian 参考。 式 (7.2.8) 与动态 OT 尤其相似，若参考 R_ε（$\varepsilon > 0$）为[8]

$$dx_t = \sqrt{\varepsilon}\,dw_t, \qquad f \equiv 0, \quad g(t) \equiv \sqrt{\varepsilon}.$$

SB 在匹配端点的同时最少偏离该 Brownian 路径律：

$$\mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_P D_{\mathrm{KL}}(P\|R_\varepsilon), \qquad P_0 = p_{\mathrm{src}}, \quad P_T = p_{\mathrm{tgt}}. \tag{7.2.9}$$

等价控制形式为

$$\mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \min_{\substack{v_t:\ dx_t=v_t(x_t)dt+\sqrt{\varepsilon}\,dw_t \\ x_0\sim p_{\mathrm{src}},\ x_T\sim p_{\mathrm{tgt}}}} \frac{1}{2\varepsilon}\int_0^T \int_{\mathbb{R}^D} \|v_t(x)\|^2 p_t(x)\,dx\,dt, \tag{7.2.10}$$

p_t 是该受控扩散的时间边缘。**译注：** 原脚注的时间对称形式须说明正则强度缩放和端点熵项：以当前速度 $\widetilde{v} = v - (\varepsilon/2)\nabla \log \rho$ 展开后，$\varepsilon D_{\mathrm{KL}}$ 含脚注所列动能与 Fisher 项，另有固定端点下的熵差常数。它不是不经缩放、无边界项便逐字等于上式 D_{KL} 的恒等式。

为何要指定参考分布？ 经典 OT 无需参考路径分布，底层代价已规定源点与目标点配对有多贵，可直接按代价比较耦合。SB 比较的是整条随机轨迹，因此需要 R 来说明无控制动力学的常态；$D_{\mathrm{KL}}(P\|R)$ 衡量为满足端点分布，过程须偏离这一常态多少。

耦合 PDE 刻画。 用两个时空势 $\Psi(x,t), \widehat{\Psi}(x,t)$ 描述 SB 解。令 p_t^{SB} 为式 (7.2.7) 最优路径律 P^* 的时间边缘，有对称分解（Dai Pra, 1991）

$$p_t^{\mathrm{SB}}(x) = \Psi(x,t)\widehat{\Psi}(x,t). \tag{7.2.11}$$

两势解线性 Schrödinger 系统（Caluya and Halder, 2021; Chen et al., 2021; Chen et al., 2022）：

$$\begin{aligned} \partial_t \Psi(x,t) &= -\nabla_x \Psi(x,t)\cdot f(x,t) - \frac{g^2(t)}{2}\Delta_x \Psi(x,t), \\ \partial_t \widehat{\Psi}(x,t) &= -\nabla_x \cdot \big(\widehat{\Psi}(x,t) f(x,t)\big) + \frac{g^2(t)}{2}\Delta_x \widehat{\Psi}(x,t), \\ \Psi(x,0)\widehat{\Psi}(x,0) &= p_{\mathrm{src}}(x), \qquad \Psi(x,T)\widehat{\Psi}(x,T) = p_{\mathrm{tgt}}(x). \end{aligned} \tag{7.2.12}$$

[8]原注：这种相似性可精确化。在等价的时间对称流体动力学形式中，若当前速度 $\widetilde{v}_t$ 满足连续性方程 $\partial_t \rho_t + \nabla\cdot(\rho_t \widetilde{v}_t) = 0$，则 Brownian 参考 SB 目标式 (7.2.10)，至多相差惯用常数因子，可写为 Benamou–Brenier 型动能加 Fisher 信息项：

$$\int_0^T \int \left[\frac{1}{2}\|\widetilde{v}_t(x)\|^2 + \frac{\varepsilon^2}{8}\|\nabla_x \log \rho_t(x)\|^2\right] \rho_t(x)\,dx\,dt.$$

因此 Brownian 参考、二次代价下的熵正则 OT 可视为动态 OT 的 Fisher 信息正则版本；见 Chen et al. (2021) 问题 4.6。

正向时间 Schrödinger 桥 SDE。 已知 Ψ 后，最优动力学是经时空因子倾斜的参考扩散：

$$dx_t = [f(x_t,t) + g^2(t)\nabla_x \log \Psi(x_t,t)]\,dt + g(t)\,dw_t, \qquad x_0 \sim p_{\text{src}}. \tag{7.2.13}$$

令其轨迹律为 Q。由式 (7.2.11)、(7.2.12)，$Q_0 = p_{\text{src}}, Q_T = p_{\text{tgt}}$，且 $Q = P^*$；控制极小化解为 (Chen et al., 2021，第 4.6 节)

$$v_t^*(x) = g^2(t)\nabla_x \log \Psi(x,t).$$

该漂移校正恰是匹配端点所需的最小 KL 扰动。

逆向时间 Schrödinger 桥 SDE。 同一最优路径律也可逆向生成。扩散时间反转恒等式为

$$b^-(x,t) = b^+(x,t) - g^2(t)\nabla_x \log p_t^{\text{SB}}(x),$$

其中 $b^+ = f + g^2\nabla \log \Psi$、$p_t = \Psi\widehat{\Psi}$，故

$$b^-(x,t) = f(x,t) - g^2(t)\nabla_x \log \widehat{\Psi}(x,t).$$

逆时间 SDE 为

$$dx_t = [f(x_t,t) - g^2(t)\nabla_x \log \widehat{\Psi}(x_t,t)]\,dt + g(t)\,d\overline{w}_t, \qquad x_T \sim p_{\text{tgt}}. \tag{7.2.14}$$

等价地，令 $y_\tau := x_{T-\tau}$、τ 从 0 增至 T，从 $y_0 \sim p_{\text{tgt}}$ 正向演化：

$$\begin{aligned} dy_\tau = {} & [-f(y_\tau, T-\tau) + g^2(T-\tau)\nabla_y \log \widehat{\Psi}(y_\tau, T-\tau)]\,d\tau \\ & + g(T-\tau)\,dw_\tau. \end{aligned} \tag{7.2.15}$$

两种描述产生同一最优路径律，由

$$\nabla \log p_t^{\text{SB}} = \nabla \log \Psi + \nabla \log \widehat{\Psi}, \qquad b^- = b^+ - g^2\nabla \log p_t^{\text{SB}}$$

相联系，因而每时刻边缘均为 p_t^{SB}。附加正向漂移 $g^2\nabla \log \Psi$ 及逆向漂移 $-g^2\nabla \log \widehat{\Psi}$ 充当控制力，使过程匹配端点，同时相对熵上最接近参考。

耦合 PDE 方法的实际障碍。 要用式 (7.2.14) 生成，须解式 (7.2.12) 求逆向势 $\widehat{\Psi}$；低维下也往往很难。替代方案包括：借助得分 SDE 迭代求解各半桥（$p_{\text{tgt}} \leftarrow p_{\text{src}}$ 及 $p_{\text{tgt}} \rightarrow p_{\text{src}}$；De Bortoli et al., 2021）；优化似然代理界（Chen et al., 2022; Liu et al., 2023）；或利用独立样本对 $(x_0, x_T) \sim p_{\text{src}} \otimes p_{\text{tgt}}$ 的后验 $x_t \mid x_0, x_T$ 解析解，设计无需模拟的训练（Liu et al., 2023）。这里不深入技术，扩散与 SB 联系见第 7.4 节。

7.2.4 全局推前与局部动力学：DGM 的 OT 类比

从式 (7.2.1) 的 OT 视角，可用 DGM 学习简单先验到数据的推前映射 $G_{\phi\#}p_{\text{prior}} \approx p_{\text{data}}$。它一般不等于最优映射，除非像 Genevay et al. (2018)、Onken et al. (2021) 等在适当条件下施加 OT 目标。式 (7.2.3) 提供互补动态视角：不直接学单个全局映射，而用时变局部向量场生成连续流，在先验与数据间描绘平滑路径。这类比于静态 SB 式 (7.2.7) 与随机控制式 (7.2.8) 的关系，最优耦合由受控扩散实现。生成建模也有类似对应：GAN 或 VAE 等标准 DGM 学习全局推前，扩散则学习驱动生成动力学的时变局部向量场。

7.3 不同最优传输表述的关系

深入细节前，先看 OT 与熵正则形式如何联系。图 7.4 给出四项关系：

(i) **路径空间 SB $\Longleftrightarrow$ 随机控制 SB**。相对于选定参考过程，路径 KL 与控制形式描述同一桥问题，见第 7.2.3 节。

(ii) **Brownian 参考 SB $\Longleftrightarrow$** EOT_ε。对 $dx_t = \sqrt{\varepsilon}\, dw_t$ 及相应二次代价归一化，最优路径律的端点耦合解相应 EOT，见第 7.3.1 节。

(iii) $\mathrm{EOT}_\varepsilon \longrightarrow$ **静态 OT**。$\varepsilon \to 0$ 时，熵正则端点耦合趋向经典 OT；适当假设下最优值收敛，见第 7.3.2 节。

(iv) $\mathrm{SB}_\varepsilon \longrightarrow$ **动态 OT**。在相应小噪声缩放下，Brownian 参考 Schrödinger 问题趋向 Benamou–Brenier 形式，见第 7.3.3 节。

这些非平凡关系将随机控制、熵正则和经典 OT 框架联系起来。

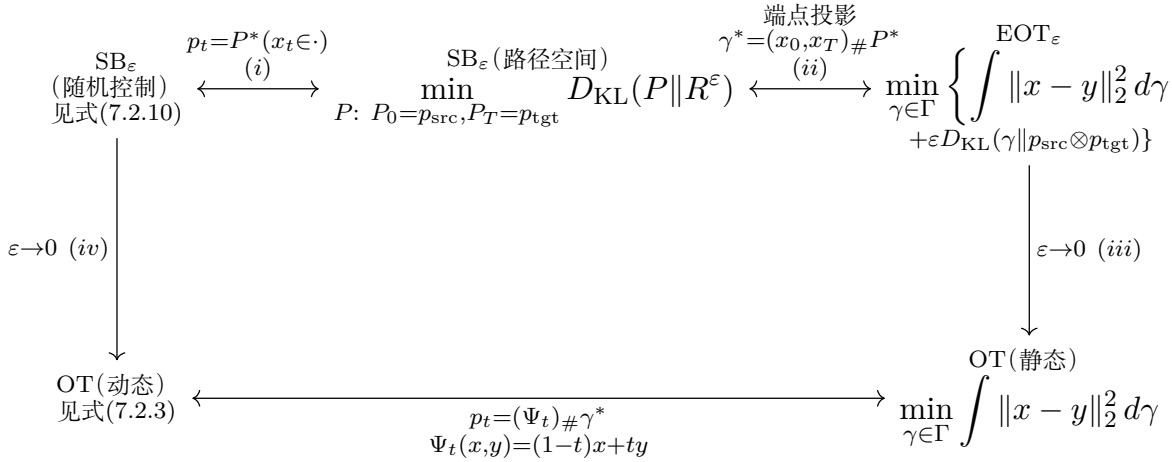


图 7.4: 二次代价及 SB 参考 R^ε 下各表述的关系。(i) 控制与路径 KL 等价；(ii)Brownian 参考及相应二次代价归一化下，SB 端点投影给出 EOT；(iii) 小正则极限得到静态 OT；(iv) 适当缩放的小噪声 Schrödinger 问题趋向动态 OT。来源：作者绘制；按源物理 229 页以可编辑数学箭头图重建。

7.3.1 SB 与 EOT 的（对偶）等价

从两个互补视角说明其本质等价。不同于产生单个确定性映射的经典 OT，SB 产生随机粒子流：质量按概率输运，边缘依扩散型动力学演化。静态视角下，SB 等于在代价与熵之间平衡的端点耦合 EOT；动态视角下，SB 是尽量接近简单参考、又满足端点的受控扩散。两者分别给出 SB/EOT 作为分布变换规范形式的一致理解。[9]

[9]译注：经典 OT 有单个确定性最优映射，须连同前述 Brenier 等条件理解；一般 Kantorovich 问题的最优耦合不必是映射，也不必唯一。

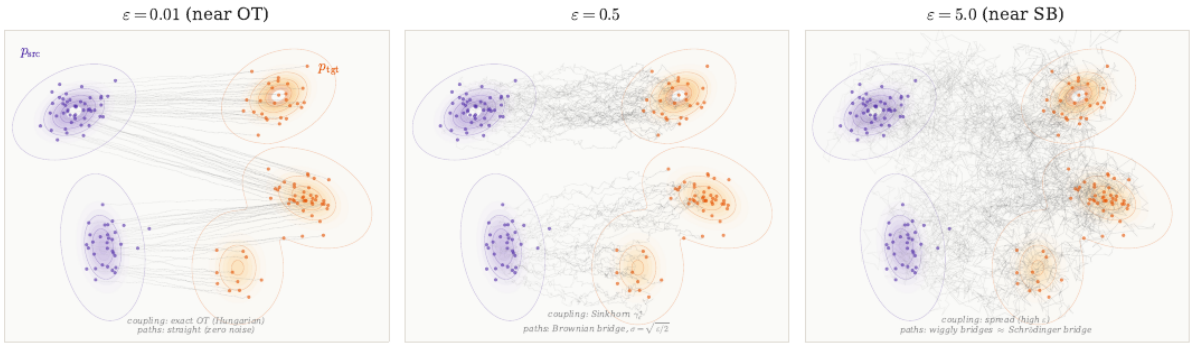


图 7.5: 熵正则强度 ε 的影响，对应 (iii)/(iv)。ε 增大时，耦合向更远目标铺展，路径也更随机。左（$\varepsilon = 0.01$）路径近直线、每点匹配附近单个目标，恢复经典 OT；中（0.5）有可见涨落、耦合开始铺展；右原图注写 2.5，路径高度随机、趋向 Schrödinger 桥情形。$\varepsilon \to \infty$ 时耦合趋向独立乘积。耦合由 Sinkhorn 计算，零正则极限用 Hungarian；给定端点，按第 7.3.1 节 Mikami 对应，路径为扩散系数 $\sigma = \sqrt{\varepsilon/2}$ 的 Brownian 桥。来源：作者借助 AI 辅助编程绘制；取自源物理 230 页。译注：图内右列标 $\varepsilon = 5.0$，与原图注 2.5 不一致；保留图和原注两者，不据示意图反推实验参数。

静态 Schrödinger 桥。 令

$$\widetilde{R}^{\varepsilon}(x,y) := Z_{\varepsilon}^{-1} e^{-c(x,y)/\varepsilon} p_{\mathrm{src}}(x) p_{\mathrm{tgt}}(y),$$
$$Z_{\varepsilon} := \iint e^{-c(x,y)/\varepsilon} p_{\mathrm{src}}(x) p_{\mathrm{tgt}}(y)\, dx\, dy.$$

对任意可行 $\gamma \in \Gamma(p_{\mathrm{src}}, p_{\mathrm{tgt}})$，直接计算有

$$\int c\, d\gamma + \varepsilon D_{\mathrm{KL}}(\gamma \| p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}) = \varepsilon D_{\mathrm{KL}}(\gamma \| \widetilde{R}^{\varepsilon}) - \varepsilon \log Z_{\varepsilon}.$$

故

$$\min_{\gamma \in \Gamma} \left\{ \int c\, d\gamma + \varepsilon D_{\mathrm{KL}}(\gamma \| p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}) \right\} = \varepsilon \min_{\gamma \in \Gamma} D_{\mathrm{KL}}(\gamma \| \widetilde{R}^{\varepsilon}) - \varepsilon \log Z_{\varepsilon}. \tag{7.3.1}$$

EOT 至多相差加法常数，等价于静态 SB $\min_{\gamma \in \Gamma} D_{\mathrm{KL}}(\gamma \| \widetilde{R}^{\varepsilon})$。

Brownian 参考下的动态等价。 经典结果（Mikami and Thieullen, 2006）表明，二次代价 $c(x,y) = \|y - x\|^2/(2T)$ 的 EOT，与参考为 $[0,T]$ 上 Brownian 运动 $dx_t = \sqrt{\varepsilon}\, dw_t$ 的 SB 仿射等价：最优值只差正缩放和与决策无关的加法常数，极小化解相同。若 P^* 为最优 SB 路径律，端点 (x_0, x_T) 诱导

$$\gamma^* := (x_0, x_T)_{\#} P^*,$$

它是相应 EOT 最优方案。反过来，先从 EOT 最优 γ^* 抽端点，再从给定端点的参考扩散抽条件路径；以 γ^* 混合这些桥，便恢复 P^*。EOT 决定两端如何配对，参考扩散决定每对端点之间最优的随机路径。

关键在于，路径 KL 可按两端点分解，SB 便化为端点联合分布的 KL。Brownian 转移密度是高斯，负对数为二次式：

$$-\varepsilon \log p_T(y \mid x) = \frac{\|y-x\|^2}{2T} + \text{常数}.$$

所以端点 KL 与二次 EOT 目标只差无关常数。**译注：**图 7.4 采用未除 $2T$ 的平方代价记号，而本段用 $\|y-x\|^2/(2T)$；Brownian 扩散强度和 EOT 正则系数须配套缩放。图 7.5 的 $\sqrt{\varepsilon/2}$ 也是其代价归一化下的系数，不应与此处 $\sqrt{\varepsilon}$ 不加区分地混用。

一般参考决定端点 EOT 代价。 联系不限于 Brownian 运动。适定参考的转移律说明从 x 到 y 有多“自然”；不太可能的配对应有较高代价。若 $p_T(y \mid x)$ 为参考在 $[0,T]$ 的转移密度，则至多相差缩放和只依赖固定边缘的加法项，

$$c(x,y) \propto -\log p_T(y \mid x).$$

可能性高的转移代价小，低的代价大。完整参考还包含端点代价之外的信息：选定端点后，它决定连接端点的条件随机路径。EOT 给出最优配对，SB 进一步描述各配对之间的随机输运。

7.3.2 $\varepsilon \to 0$ 时 EOT 约化为 OT

记 γ_ε^* 为 EOT 最优方案、γ^* 为无正则式 (7.2.1) 的最优方案。标准假设下，正则强度趋零时最优值趋向 OT 值，任何极限方案都是 OT 最优；若 OT 解唯一，整个最优方案收敛于它。这一结果支持用小正则的 Sinkhorn 等高效数值解作为经典 OT 的可计算近似，代价不必限定为二次。

定理 7.3.1（（非正式）EOT 收敛到 OT)**.** *在保证熵正则 OT 极限的标准假设下，*

$$\lim_{\varepsilon \to 0} \mathrm{EOT}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = \mathrm{OT}(p_{\mathrm{src}}, p_{\mathrm{tgt}}).$$

任何最优方案极限都是无正则 OT 的最优耦合；若 OT 解唯一，熵正则最优方案收敛到该解。

证明. 严格证明见 Mikami and Thieullen (2008)、Peyré, Cuturi, et al. (2019)。这里只给最优值收敛的启发推导。简记 $V_\varepsilon := \mathrm{EOT}_\varepsilon$、$V_0 := \mathrm{OT}$。以下初等上界要求某个 OT 最优耦合相对于边缘乘积的 KL 有限；一般情形需以有限熵耦合逼近，或系统地用 Γ 收敛论证。

上界。由最优性，

$$V_\varepsilon \le \int c\, d\gamma^* + \varepsilon D_{\mathrm{KL}}(\gamma^* \| p_{\mathrm{src}} \otimes p_{\mathrm{tgt}}).$$

若 KL 为有限常数 K，则 $V_\varepsilon \le V_0 + \varepsilon K$，从而 $\limsup_{\varepsilon \to 0} V_\varepsilon \le V_0$。

下界。KL 非负，故 $V_\varepsilon \ge \int c\, d\gamma_\varepsilon^* \ge V_0$，于是 $\liminf_{\varepsilon \to 0} V_\varepsilon \ge V_0$。两界合并给出值收敛。方案收敛还需额外紧性：极限点为 OT 最优，唯一性再给出全收敛。 □

7.3.3 $\varepsilon \to 0$ 时 SB 约化为 OT

为直接比较式 (7.2.3)，本小节缩放时间使 $T = 1$。令 v_t^ε 为式 (7.2.10) 的极小化控制，p_t^ε 为相应受控 SDE 边缘，满足 Fokker–Planck 方程；以 (p_t^0, v_t^0) 记 Benamou–Brenier 的极小化解。如下定理[10]说明小噪声 SB 趋向 OT。它同样支持用可高效求解、可微的 Sinkhorn 型 SB 近似高维大规模 OT，直接动态求解器此时可能昂贵。

定理 7.3.2（（非正式）SB 收敛到 OT）**.** *当 $\varepsilon \to 0$，*

$$\lim_{\varepsilon \to 0} 2\varepsilon \, \mathrm{SB}_\varepsilon(p_{\mathrm{src}}, p_{\mathrm{tgt}}) = W_2^2(p_{\mathrm{src}}, p_{\mathrm{tgt}}).$$

右端为式 (7.2.3) 的 Benamou–Brenier 形式。适当紧性、正则条件下，边缘及相应速度沿子列，以恰当弱意义收敛到求解动态 OT 的 (p_t^0, v_t^0)；若动态 OT 极小化解唯一，最优 Schrödinger 动力学在相应极限意义下收敛到该 OT 解。

证明. 完整严格证明超出本书范围，参见 Léonard (2012, 2014)。启发地，控制式的

$$dx_t = v_t^\varepsilon(x_t)\, dt + \sqrt{\varepsilon}\, dw_t$$

在噪声趋零时形式上趋向确定性 ODE $dx_t = v_t^0(x_t)dt$，结合式 (7.2.10) 便提示适当缩放目标趋向动能 W_2^2。同时，

$$\partial_t p_t^\varepsilon + \nabla \cdot (p_t^\varepsilon v_t^\varepsilon) = \frac{\varepsilon}{2} \Delta p_t^\varepsilon$$

形式上约化为连续性方程

$$\partial_t p_t^0 + \nabla \cdot (p_t^0 v_t^0) = 0.$$

□

至此已在各自假设下介绍 EOT 与 SB 的基本等价，以及它们经极限联系 OT 的方式，见图 7.4。下面转向扩散模型。

7.4 扩散 SDE 是 SB 问题的最优解吗？

7.4.1 扩散模型作为 Schrödinger 桥的特例

SB 通过来自时空势 $\Psi, \widehat{\Psi}$ 的控制漂移，使参考扩散匹配指定端点，允许任意源目标间的非线性插值，并有

$$\nabla \log \Psi(x,t) + \nabla \log \widehat{\Psi}(x,t) = \nabla \log p_t^{\mathrm{SB}}(x).$$

因此可超越标准高斯先验，覆盖更广的分布。

[10]原注：严格表述使用适当缩放 Schrödinger 泛函的 Γ 收敛，再结合紧性得到最优值和极小化解极限点收敛。技术背景较多，此处省略细节，只陈述概念结果。

与扩散模型的联系。 若势恒为 $\Psi(x,t)\equiv 1$，式 (7.2.12) 的第二个 PDE 化为标准 Fokker–Planck 方程，其解是参考过程边缘：

$$\widehat{\Psi}(x,t)=p_t^{\mathrm{SB}}(x). \tag{7.4.1}$$

SB 正向 SDE 于是变为无控制参考过程

$$dx_t=f(x_t,t)\,dt+g(t)\,dw_t,$$

逆向 SDE 简化为

$$dx_t=[f(x_t,t)-g^2(t)\nabla\log p_t^{\mathrm{SB}}(x_t)]\,dt+g(t)\,d\overline{w}_t,$$

正是扩散模型中的 Anderson 逆时间 SDE。扩散模型因而可看作 SB 的零控制极限，势不引入额外漂移。

边界条件与一般性。 除非边界相容，上述约化只是形式的。任意给定 $(p_{\mathrm{src}},p_{\mathrm{tgt}})$ 时，$\Psi\equiv 1$ 一般不满足式 (7.2.12) 的两端约束。完整 SB 通过非平凡势产生非线性控制，弯曲参考动力学以匹配指定端点；扩散则固定一个简单先验端点，学习逆得分返回数据。因此 SB 是更灵活的总框架：非平凡势连接任意端点，常势则约化为上述扩散情形。标准线性扩散中，原文指出 $p_T\approx p_{\mathrm{prior}}$ 只在 $T\to\infty$ 时成立，故先验匹配仅为近似。

7.4.2 扩散模型作为 Schrödinger 半桥

半桥只约束一个端点（先验或数据），而非两个，是完整桥的单侧放松。先从一般源目标定义它，再回到先验与数据端点。

Schrödinger 半桥。 完整 SB 要求既最接近简单参考，又匹配两端，计算常常困难。令 R 为参考路径分布，正向半桥是

$$\min_{P:P_0=p_{\mathrm{src}}} D_{\mathrm{KL}}(P\|R),$$

仅约束初始边缘；逆向半桥则为

$$\min_{P:P_T=p_{\mathrm{tgt}}} D_{\mathrm{KL}}(P\|R),$$

仅约束终端边缘。前者问所有从指定分布出发的过程中哪个最像参考，后者问以指定分布结束的过程。迭代组合这两个放松可逼近完整桥。

扩散缺少精确端点匹配。 标准扩散的正向 SDE 通常对 x_t 线性（原式 4.4.2），设计为仅在 $T\to\infty$ 时满足 $p_T\approx p_{\mathrm{prior}}$。有限时间的 p_T 是 $\alpha_T x_0+\sigma_T\epsilon$ 的分布，一般仍依赖数据，不必精确等于给定高斯，见附录 C.1.5。相比之下，SB 引入控制 $g^2\nabla_x\log\Psi$，在有限 T 强制匹配 $p_0=p_{\mathrm{data}}$、$p_T=p_{\mathrm{prior}}$。概括为：

- 扩散：$T\to\infty$ 时渐近 $p_T\approx p_{\mathrm{prior}}$；

- SB：求解两势后，在有限 T 精确满足 $p_T = p_{\text{prior}}$。

译注：此处渐近比较针对所讨论的常规正则线性加噪过程；前文允许的奇异有限终点调度须另处理，不能把“仅 $T \to \infty$”提升为所有可能调度的定理。完整 SB 对端点的可实现性和势解存在也需适用条件。原式 4.4.2 定位按源保留，本段线性 SDE 的一般形式并不限于该具体 VP 例子。

扩散 Schrödinger 桥。 相对于所选参考，固定正向加噪可看作锚定数据的正向半桥；终端是参考过程自然产生的分布，一般只近似先验，因而不是指定 $(p_{\text{data}}, p_{\text{prior}})$ 的完整桥。Diffusion Schrödinger Bridge（DSB；De Bortoli et al., 2021）采用迭代比例拟合（IPF）的交替投影思想，轮流匹配两端，扩展为完整 SB：[11]

0. **参考过程**。初始化 $P^{(0)} := R_{\text{fwd}}$，即

$$dx_t = f(x_t, t)\,dt + g(t)\,dw_t, \qquad x_0 \sim p_{\text{data}}.$$

于是 $P_0^{(0)} = p_{\text{data}}$，通常 $P_T^{(0)} \neq p_{\text{prior}}$。

1. **逆向一步**。计算既匹配终端先验、又最接近 $P^{(0)}$ 的过程：

$$P^{(1)} = \operatorname*{arg\,min}_{P: P_T = p_{\text{prior}}} D_{\text{KL}}(P \| P^{(0)}).$$

用神经网络 $s_{\phi\times}$ 近似理想得分，得到从 $x_T \sim p_{\text{prior}}$ 逆向模拟的

$$dx_t = [f(x_t, t) - g^2(t) s_{\phi\times}(x_t, t)]\,dt + g(t)\,d\overline{w}_t.$$

迭代。 $P_T^{(1)} = p_{\text{prior}}$，但 $P_0^{(1)}$ 通常偏离数据。IPF 再学正向 SDE 把初始边缘调回数据，之后再次逆向强制先验；交替细化直至收敛到两端均匹配的最优桥 P^*。De Bortoli et al. (2021) 在温和条件下证明收敛。**译注：**这里的精确 KL 投影/端点匹配与网络近似实现须区分；有限拟合及数值积分误差不自动服从理想 IPF 收敛结论。若参考本身已以数据初始化，单初始约束的半桥最优值为零，最优律就是该参考；不意味着同时满足另一个指定端点。

DSB 在历史与概念上重要，但实践可能昂贵：每轮正逆投影需解单独的得分匹配问题，近似误差还可跨轮累积。后续工作改进 SB 的稳定性、可扩展性，有些也降低重复拟合单独扩散模型的依赖。此处不详述，保留原引用键 `shi2023dsbm; liu2024gsbm`，供读者定位更广的实用 SB 文献，不猜补损坏的作者年份。

7.5 扩散模型的 ODE 是 OT 问题的最优映射吗？

本节聚焦二次代价最优传输问题。

7.5.1 PF-ODE 流通常不是最优传输

扩散过程诱导的确定性流映射，是否等于二次代价下的最优传输映射？一般而言，答案是否定的；即便在高斯情形，已有显式反例。原文引用键 `tanana2017comparison` 指出：若扩散流

[11] 原注：虽然用数据与先验描述，DSB 适用于任意一对端点分布。

采用更一般的高斯参考，即使两端均为高斯，所得确定性输运映射也可能不同于 Brenier 最优映射。在该情形两映射均可显式写出，可直接比较。这里保留原引用键，不猜补未正常显示的作者年份。

下面介绍 Lavenant and Santambrogio (2022) 在标准高斯 Ornstein–Uhlenbeck 设定中的更强构造，它直接关联扩散模型，涉及更广的初始分布，并揭示 PF-ODE 映射何以不必最优。

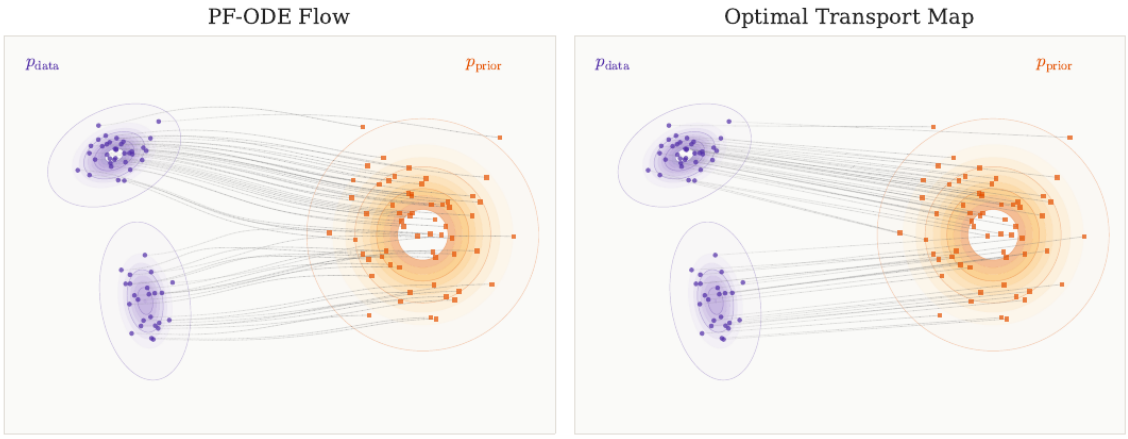


图 7.6: 二维中从 p_{data} 到 p_{prior} 的 PF-ODE 流映射（左）与最优传输映射（右）的比较。右图用 Hungarian 算法精确求得二次代价分配，左图通过积分 PF-ODE 获得；两者明显不同，示意 PF-ODE 通常不恢复 OT 映射。图内英文依次为 PF-ODE 流、最优传输映射。来源：作者借助 AI 辅助编码制作。译注：Hungarian 算法的精确性针对图中有限样本的分配问题，图示本身不构成连续分布下的一般非最优性证明。

设定。 考虑 VP SDE 中的 Ornstein–Uhlenbeck 过程，把光滑初始密度 p_0 演化至标准高斯 $\mathcal{N}(0, I)$：

$$dx(t) = -x(t)\,dt + \sqrt{2}\,dw(t), \qquad x(0) \sim p_0.$$

相应 PF-ODE 为

$$\frac{dS_t(x)}{dt} = -S_t(x) - \nabla \log p_t(S_t(x)), \qquad S_0(x) = x.$$

S_t 将 p_0 推前为边缘 p_t，即

$$(S_t)_{\#}p_0 = p_t, \qquad p_t(y) = \int_{\mathbb{R}^D} \delta(y - S_t(x)) p_0(x)\,dx.$$

这些密度服从 Fokker–Planck 方程

$$\partial_t p_t = \nabla \cdot (x p_t) + \Delta p_t,$$

等价于速度场

$$v_t(x) = -x - \nabla \log p_t(x)$$

的连续性方程，其流为 S_t，即 $dS_t(x)/dt = v_t(S_t(x))$。当 $t \to \infty$ 时，终端映射输运至先验：

$$(S_\infty)_{\#}p_0 = \mathcal{N}(0, I) =: p_{\text{prior}}.$$

Lavenant and Santambrogio (2022) 论证的目标。 他们不直接判断从 p_0 到高斯的终端映射 S_∞ 是否最优，而是构造特定 p_0，考察整条 PF-ODE 轨迹；关键是最优性可能在流的某处失效。对中间边缘 $p_t = (S_t)_\# p_0$，定义剩余映射

$$T_{t\to\infty} := S_\infty \circ S_t^{-1}, \qquad t \geq 0.$$

论证表明，对精心选定的 p_0，存在 $t_0 \geq 0$，使 $T_{t_0\to\infty}$ 不是从新起点分布 p_{t_0} 到 $\mathcal{N}(0, I)$ 的二次代价最优映射。因此 PF-ODE 流一般不保证最优。**译注：** 下文是光滑可逆流和足够良好终端极限下的证明纲要；有限时流可逆不自动保证无限时极限可逆。存在上述 t_0，不能单凭此步断言同一原始 p_0 的 S_∞ 已非最优。

所需工具。 论证依赖 Brenier 定理：

定理 7.1 (非正式 Brenier 定理)**.** *设 ν_1, ν_2 是 $\mathbb{R}^D$ 上具有光滑密度的概率分布。光滑映射 $T : \mathbb{R}^D \to \mathbb{R}^D$ 是从 ν_1 到 ν_2 的二次代价最优传输，当且仅当存在凸函数 u，使 $T = \nabla u$。此时 DT 对称半正定，u 满足 Monge–Ampère 方程*

$$\det D^2 u(x) = \frac{\nu_1(x)}{\nu_2(\nabla u(x))}.$$

译注： 这是源文的非正式光滑表述。须先要求 $T_\# \nu_1 = \nu_2$，通常还假设有限二阶矩和源分布绝对连续；凸梯度刻画按源分布几乎处处理解。光滑性本身不提供所有存在、可逆或逐点 Monge–Ampère 结论。此处沿用源文特例编号 “定理 7.1”，不改前面的节内编号。

证明还隐含使用：在适用的可逆设定下，一个映射是两分布间的最优传输，当且仅当其逆是反向最优传输；后文不逐次重述。

证明纲要：PF-ODE 通常不是 OT 映射。 采用反证法，假设对每个 $t \geq 0$，

$$T_t = S_t \circ S_\infty^{-1}$$

均为从 $\mathcal{N}(0, I)$ 到 p_t 的二次代价最优映射。注意 T_t 与上面的剩余映射互逆。

第 1 步：Brenier 定理。 高斯出发的最优映射，其 Jacobian 须对称半正定，故

$$DT_t(x) = DS_t(S_\infty^{-1}(x)) D(S_\infty^{-1})(x)$$

须对所有 t, x 对称，其中 D 表示关于空间变量的全微分。

第 2 步：对对称条件作时间微分。 有

$$\partial_t DT_t(x) = (\partial_t DS_t)(S_\infty^{-1}(x)) D(S_\infty^{-1})(x).$$

既然矩阵始终对称，其时间导数也对称。对流 ODE 作空间微分得到

$$\partial_t DS_t = Dv_t(S_t) DS_t = \big(-I - D^2 \log p_t(S_t)\big) DS_t.$$

因此（各复合映射的取值点如上）

$$\big(-I - D^2 \log p_t(S_t)\big) DS_t D(S_\infty^{-1})$$

对所有 $t \geq 0$ 对称。在 $t = 0$，$S_0 = I$、$DS_0 = I$，故

$$\big(-I - D^2 \log p_0(S_\infty^{-1}(x))\big) D(S_\infty^{-1})(x)$$

对称。

第 3 步：交换条件。 假设 $T_0 = S_\infty^{-1}$ 最优，故 $D(S_\infty^{-1})$ 对称；$D^2 \log p_0$ 也对称。两个对称矩阵的乘积对称，当且仅当二者可交换。因此对所有 x，

$$D^2 \log p_0(S_\infty^{-1}(x)) \quad \text{须与} \quad D(S_\infty^{-1})(x) \quad \text{可交换.}$$

令 $y = S_\infty^{-1}(x)$，等价于对所有 $y \in \mathbb{R}^D$，

$$D^2 \log p_0(y) \quad \text{须与} \quad DS_\infty(y) \quad \text{可交换.}$$

现在将条件化为便于计算的形式。因 S_∞ 在 p_0 与标准高斯间最优，Brenier 定理给出 $S_\infty = \nabla u$，u 为凸函数。Monge–Ampère 方程意味着

$$\log p_0(y) = \log \det D^2 u(y) - \frac{1}{2}\|\nabla u(y)\|^2 + \text{常数}.$$

代入 $DS_\infty = D^2 u$，得到必要条件

$$D^2 \left(\log \det D^2 u - \frac{1}{2}\|\nabla u\|^2 \right) \quad \text{与} \quad D^2 u \quad \text{可交换.} \tag{7.5.1}$$

第 4 步：构造反例。 若能构造凸函数 u，使某处

$$D^2 \left(\log \det D^2 u(x) - \tfrac{1}{2}\|\nabla u(x)\|^2 \right)$$

与 $D^2 u(x)$ 不可交换，则定义 $p_0 = (\nabla u)_{\#}^{-1} \mathcal{N}(0, I)$。Brenier 定理保证 ∇u 是 p_0 到高斯的最优传输，但式 (7.5.1) 不成立，产生矛盾。考虑小参数 ε 下

$$u(x) = \tfrac{1}{2}\|x\|^2 + \varepsilon \phi(x).$$

于是 $D^2 u(0) = I + \varepsilon D^2 \phi(0)$。原文指出，原点的交换条件要求 $D^2\phi(0)$ 与 $D^2(\Delta\phi)(0)$ 可交换。例如在 $\mathbb{R}^2$ 中取

$$\phi(x_1, x_2) = x_1 x_2 + x_1^4,$$

即得到 $D^2 \log p_0$ 与 $D^2 u$ 不可交换的反例。因此 T_t 不能对所有 $t \geq 0$ 都最优；存在 $t_0 \geq 0$，使其逆 $T_{t_0 \to \infty}$ 不最优。**译注：** 任意小扰动的交换条件展开还需关注高阶项，原文此处为纲要。对所给具体例，取 $0 < \varepsilon < 1$，$D^2 u = \begin{pmatrix} 1 + 12\varepsilon x_1^2 & \varepsilon \\ \varepsilon & 1 \end{pmatrix}$ 确实正定。在原点，令 $A = D^2(\log\det D^2 u - \|\nabla u\|^2/2)$、$B = D^2 u$，则 $[A, B]_{12} = 24\varepsilon^2/(1 - \varepsilon^2) \neq 0$，可直接验证本例矛盾，而非把一阶展开当作精确恒等式。

7.5.2 典范线性流和 Reflow 能得到 OT 映射吗？

PF-ODE（特别是 VP 型正向核）通常不提供 OT 映射。自然会问：

问题 7.5.1. 对独立耦合 $\pi(x_0, x_1) = p_{\mathrm{src}}(x_0)p_{\mathrm{tgt}}(x_1)$，采用 $x_0 \sim p_{\mathrm{src}}$、$x_1 \sim p_{\mathrm{tgt}}$ 的线性插值流 $(1-t)x_0 + tx_1$，能恢复 *OT* 映射吗？

答案是否定的。不过，线性路径与给定耦合结合，可提供真实 OT 代价的实用上界；在连接同一对端点的条件路径中，线性插值给出最紧上界。

典范线性流与最优传输。 对二次代价，静态式 (7.2.1) 等价于 Benamou–Brenier 式 (7.2.3)：

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) := \min_{\substack{(p_t, v_t):\ \partial_t p_t + \nabla\cdot(p_t v_t) = 0 \\ p_0 = p_{\mathrm{src}},\ p_1 = p_{\mathrm{tgt}}}} \int_0^1 \int_{\mathbb{R}^D} \|v_t(x)\|^2 p_t(x)\, dx\, dt.$$

静态 Monge 表述 (7.2.2) 求最优映射需处理 Monge–Ampère 方程 (7.2.4)；Benamou–Brenier 问题引入动量场 $m_t := p_t v_t$ 后可改写为凸优化。不过在 $\mathbb{R}^D$ 的网格上离散仍难以扩展到高维。

Liu (2022) 和 Lipman et al. (2024) 指出，可把搜索限制在由耦合 $\pi_{0,1}$ 抽取固定端点 (x_0, x_1) 的条件流族，得到动能的实用上界。在此族中，典范线性插值最优：

命题 7.5.1 (条件流给出的 OT 动能上界)**.** *令 $\pi_{0,1}$ 是 p_{src} 与 p_{tgt} 的任意耦合。*

1. *对任意连接端点的条件流 $\Psi_t(x_0, x_1)$，*

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) \le \mathbb{E}_{(x_0,x_1)\sim\pi_{0,1}} \left[\int_0^1 \|\Psi_t'(x_0, x_1)\|^2\, dt \right].$$

2. *使右端上界最小的唯一条件流是线性路径*

$$\Psi_t^*(x_0, x_1) = (1-t)x_0 + tx_1.$$

代入得到此类上界中最紧的一个：

$$\mathcal{K}(p_{\mathrm{src}}, p_{\mathrm{tgt}}) \le \mathbb{E}_{(x_0,x_1)\sim\pi_{0,1}} \|x_1 - x_0\|^2.$$

证明. 对条件期望应用 Jensen 不等式与塔式法则，再用 Euler–Lagrange 方程求解简化变分问题；完整论证见 Lipman et al. (2024) 第 4.7 节。 □

换言之，对每个指定耦合，线性插值（即 Flow Matching 和 Rectified Flow 所用正向核）最小化真实动能的一个上界。*条件流族内部最优，不保证边缘分布上的全局最优。* **译注：** 上述路径须有适当绝对连续性和有限能量，唯一性按 $\pi_{0,1}$ 几乎处处的端点对理解；给定端点的 Cauchy–Schwarz 等号给出常速度直线。条件速度取条件期望才得到边缘速度，二者能量一般有 Jensen 间隙。

Reflow 与最优传输。 最朴素的计划用独立耦合把样本以直线相连，通常不最优；问题在于起终点配对低效，而不在于直线本身。Reflow 迭代地调整配对，其理想步骤保证代价不增（Liu, Gong, et al., 2022），因而自然引出收敛问题：

问题 7.5.2. *迭代应用 Rectify 算子会怎样？所得输运计划序列能收敛到最优计划吗？或者，Reflow 的不动点能给出 OT 映射吗？*

一般而言不能保证。回顾从乘积耦合 $\pi^{(0)} := p_{\mathrm{src}}(x_0)p_{\mathrm{tgt}}(x_1)$ 出发的更新

$$\pi^{(k+1)} = \mathrm{Rectify}(\pi^{(k)}).$$

每次 $k = 0, 1, \ldots$，先学速度场

$$v_t^{(k)} \in \arg\min_{u_t} \mathcal{L}(u_t \mid \pi^{(k)}),$$

其中损失（如 RF 或 FM 损失）定义于式 (5.4.1)。为简化记号，这里采用非参数速度场，而非其他地方的参数化 ϕ。更新耦合为

$$\pi^{(k+1)}(x_0, x_1) := p_{\mathrm{src}}(x_0)\, \delta\big(x_1 - \Psi_1^{(k)}(x_0)\big),$$

$\Psi_1^{(k)}$ 是从初始值 x_0 积分 $v_t^{(k)}$ 得到的 $t = 1$ 解映射。Liu, Gong, et al. (2022) 已指出，即使某耦合 π 存在使 Reflow 损失为零的速度场，即 $\mathcal{L}(v_t \mid \pi) = 0$，也不必最优。**译注：** 这里 “存在零损失场” 是比 “达到损失最小值” 更强的条件；原文将二者并写，一般最小值未必为零。代价不增也针对精确条件期望、适当 ODE 解与精确积分等理想条件，不能直接保证每次网络近似都不增。

Benamou–Brenier 框架中，最优速度是势的梯度。受此启发，Liu (2022) 额外把速度限制到梯度向量场（势流）：

$$w_t^{(k)} \in \operatorname*{arg\,min}_{\substack{u_t:\ u_t = \nabla\varphi \\ \text{某个}\varphi:\mathbb{R}^D \to \mathbb{R}}} \mathcal{L}(u_t \mid \pi^{(k)}). \tag{7.5.2}$$

其余步骤与 Rectify 相同。记相应算子为 $\mathrm{Rectify}_{\perp}$，强调投影到无旋向量场；势可依赖时间，即 $v_t = \nabla\varphi_t$。

对任意源目标耦合 π，Liu, Gong, et al. (2022) 猜想以下三者等价：

(i) π 是最优传输耦合；

(ii) π 是势整流算子的不动点，即 $\pi = \mathrm{Rectify}_{\perp}(\pi)$；

(iii) 存在梯度速度场 $v_t = \nabla\varphi_t$，使整流损失 $\mathcal{L}(v_t \mid \pi) = 0$。

但 Hertrich et al. (2025) 给出两类反例：

1. 中间分布 p_t 的支撑不连通时，可有 $\mathrm{Rectify}_{\perp}$ 的不动点，兼具零 Reflow 损失与梯度速度，仍非最优耦合。

2. 即使两端都是高斯，也存在损失任意小、与最优耦合偏离却任意大的耦合。

因此，整流流虽可得到很强的生成模型，作为一般最优传输求解器的可靠性仍有限；生成建模与严格 OT 理论之间尚有间隙，值得进一步研究。最后，输运代价不总与下游表现相关，精确 OT 映射未必带来更好的实际效果。不过，最优传输及其变体仍是许多科学和工程问题的基础，扩散模型提供了探索这些问题的有力框架。

7.6 结束语

本章从最优传输及其熵变体的角度，重新审视把一个分布输运到另一个分布的经典问题。我们回顾静态 Monge–Kantorovich 形式和动态 Benamou–Brenier 形式，后者用最小化动能代价的确定性流实现输运；继而讨论熵正则 OT 与 Schrödinger 桥，转向相对于参考过程最可能的受控扩散。从随机一侧看，扩散模型自然贴近 SB 观点；在 ODE 一侧，PF-ODE 定义确定性输运映射。然而 PF-ODE 通常不是二次代价最优映射：它是许多确定性耦合之一，未必最小化 Benamou–Brenier 作用量。

在询问是否最优之前，还有更基本的问题：两个分布何时能由确定性映射连接？很多情况下，存在性不是主要困难；适当正则假设下，常能找到可测映射 T 使 $T_{\#}p_{\mathrm{src}} = p_{\mathrm{tgt}}$。困难是超过一维后，兼具显式形式和实践稳健性的经典构造较少。一维中，单调重排通过匹配分位数给出简单答案。高维也有重要构造：Brenier 定理 7.1 在适用条件下给出二次代价最优映射；Knothe–Rosenblatt 重排通过迭代条件分布构造三角映射；Dacorogna–Moser 方法通过解散度方程的速度场构造光滑微分同胚输运。后两者原引用键分别为 `rosenblatt1952remarks`; `knothe1957contributions` 和 `dacorogna1990partial`，保留待文献表恢复。每种方法均有明确原理，也依赖结构假设或非平凡分析工具。

从这个角度看，扩散流映射提供灵活而有吸引力的另一条途径。扩散和流匹配不预先规定闭式映射，而是学习随时间变化的向量场，由其流把简单源分布推向目标。所得映射未必等于 Brenier 映射或其他经典典范构造，通常也不求解预先指定的最优传输问题；但在显式构造欠缺或难以计算的高维情形，它为基于映射的采样提供实用而富有表达力的路线。由此，扩散流应被理解为现代学习型输运机制：在确定性输运的更广图景中，它与最优映射、三角重排和基于 PDE 的构造并列。

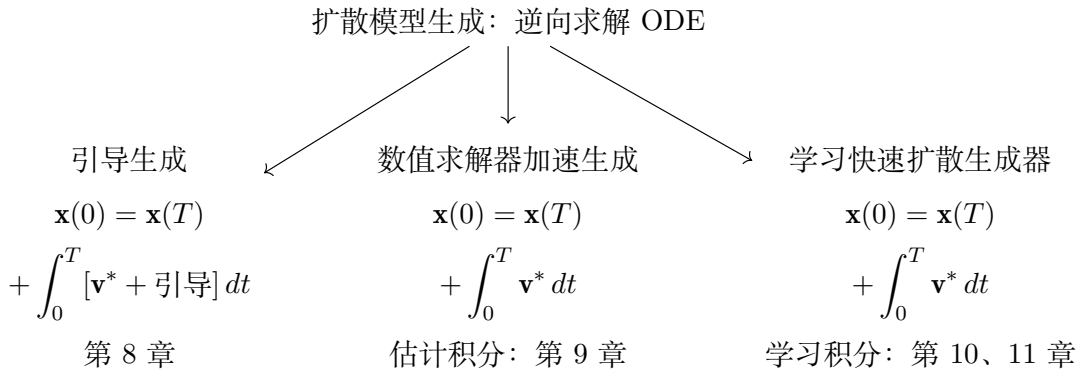
C 部：扩散模型的采样

采样路线图

第 四章的扩散模型 $\mathbf{v}^*(\mathbf{x}, t)$ 用于生成，等价于从 $\mathbf{x}(T) \sim p_{\text{prior}}$ 出发，将以下 ODE 从 T 逆向解至 0（更一般地，从 s 解至 t，其中 $s > t$）：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}^*(\mathbf{x}(t), t),$$
$$\mathbf{x}(0) = \mathbf{x}(T) + \int_0^T \mathbf{v}^*(\mathbf{x}(t), t)\, dt.$$

译注（原式保留）： 原路线图把逆时间积分写为上式的正号与 $0 \to T$ 积分。按所列 ODE 直接积分，应为 $\int_T^0 \mathbf{v}^* dt$，或 $-\int_0^T \mathbf{v}^* dt$。下面三条路线沿用图中写法，以免静默修订源图。



第八章　引导与可控生成

扩散模型是一类强大的生成框架。在无条件设定下，目标是学习 $p_{\text{data}}(\mathbf{x})$，并在没有外部输入的情况下生成样本。

然而，许多应用需要条件生成，使输出满足用户指定的标准。这既可以通过引导无条件模型实现，也可以直接学习条件分布 $p_0(\mathbf{x} \mid c)$，其中条件 c（如标签、文字描述或草图）引导生成过程。

本章从条件得分的原则性视角出发，将其分解为无条件方向与引导方向。后者推动样本满足条件，同时保持真实感。我们解释为什么需要引导，说明条件得分如何充当统一控制接口，并介绍近似或替代引导项的方法。随后区分控制（满足条件）与对齐（在给定条件下满足人类偏好），说明如何将偏好纳入同一框架。最后讨论无需额外奖励模型的直接偏好优化；奖励模型指学习到的评分器，它对更符合人类偏好的输出赋予更高评分。

学完本章后，你将能够：

- 理解条件化如何改变扩散采样使用的速度场；
- 推导分类器引导与无分类器引导的核心思想，理解引导强度如何控制条件化；
- 理解免训练引导如何使用任务损失或测量模型，引导预训练扩散模型，包括解决逆问题；
- 区分精确条件采样与替代引导动力学，以及后者的固定时刻倾斜密度解释；
- 理解从 RLHF 到 DPO 与 Diffusion-DPO 的偏好对齐如何进一步重塑条件生成模型，使其产生更受偏好的输出。

阅读路线。　本章假定读者熟悉第 4、6 章的得分 SDE/PF-ODE 图景。主要关心可控生成的读者，可在第二遍阅读后面的偏好对齐材料。

8.1　序幕

扩散模型的生成过程由粗到细推进，为可控生成提供了灵活框架。每一步去除少量噪声，样本逐渐清晰，展现更多结构与细节。由此可以控制生成过程：在学习到的时变速度场中加入引导项，使生成轨迹体现用户意图。

基于引导的扩散采样，其原则性基础是条件得分的 Bayes 分解。对每个噪声水平 t，

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid c) = \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件方向}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t)}_{\text{引导方向}}. \tag{8.1.1}$$

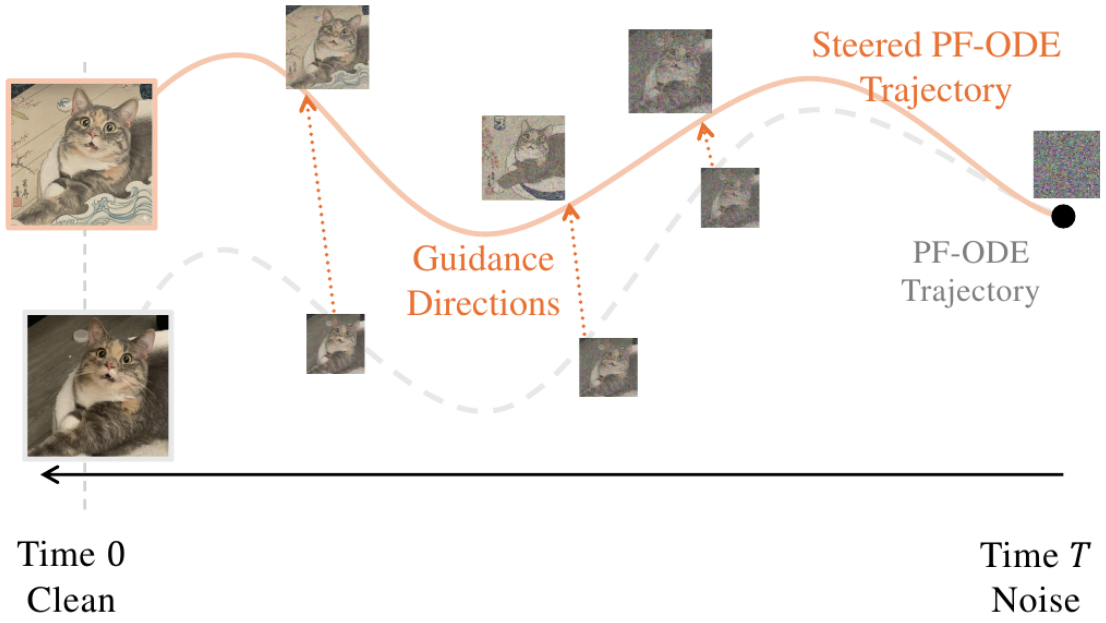


图 8.1: 引导扩散采样示意。逆时间 PF-ODE 采样从右端的纯噪声（$t = T$）出发，逐渐演化到左端的干净样本（$t = 0$）。在此过程中，随时间变化、由 w_t 加权的引导方向修改无条件得分场，使轨迹趋向期望属性（日式绘画风格）；样本则逐渐由粗到细地细化。图中 Steered PF-ODE Trajectory、PF-ODE Trajectory、Guidance Directions 依次为引导后的 PF-ODE 轨迹、PF-ODE 轨迹、引导方向。来源：原作者绘制。

这表明，在无条件得分上加入引导项 $\nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t)$，就得到精确条件逆向动力学。后面将看到，分类器引导（Dhariwal and Nichol, 2021）直接估计此项；无分类器引导（Ho and Salimans, 2021）以联合学习的条件和无条件得分之差隐式估计它；更一般的免训练方法则可能使用任务特定的替代引导方向。

使用精确条件得分时，PF-ODE 变为

$$\begin{aligned}\frac{d\mathbf{x}(t)}{dt} &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t) \mid c)}_{\text{条件得分}} \\ &= f(t)\mathbf{x}(t) - \frac{1}{2}g^2(t)\left[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}(t)) + \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}(t))\right]. \end{aligned} \tag{8.1.2}$$

若得分与积分均精确，且从相应终端边缘 $p_T(\mathbf{x}_T \mid c)$ 初始化，该动力学恢复 $p_0(\mathbf{x}_0 \mid c)$。标准扩散构造通过选择终端加噪，使通常不依赖条件的先验近似匹配 $p_T(\mathbf{x}_T \mid c)$。

为清晰起见，以下使用得分预测表述。在相应转换有定义处，标准的 $\mathbf{x}$、$\boldsymbol{\epsilon}$、得分和 $\mathbf{v}$ 预测参数化由时变线性变换联系，因此同一引导修正也可借助式 (6.3.1) 的关系，表示为其他参数化。

引导方向的具体形式。

1. **分类器引导（CG）。**第 8.2 节在加噪数据 $\mathbf{x}_t$（将带标签干净样本污染至水平 t 得到）上训练时间条件分类器 $p_\psi(c \mid \mathbf{x}_t, t)$。采样时，其输入梯度提供引导项

$$\nabla_{\mathbf{x}_t} \log p_\psi(c \mid \mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t),$$

再将其加入无条件得分（Dhariwal and Nichol, 2021）。

2. **无分类器引导（CFG）**。第 8.3 节直接训练单个条件模型

$$\mathbf{s}_\phi(\mathbf{x}_t, t, c) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid c).$$

在部分训练步骤中，随机将条件替换为特殊空标记，从而联合学习无条件模型。

3. **免训练（替代）引导**。在标准正向加噪构造中，先抽取 $(\mathbf{x}_0, c) \sim p_{\text{data}}$，再抽取 $\mathbf{x}_t \sim p_t(\cdot \mid \mathbf{x}_0)$，其中正向核不另外依赖 c，所以 $c \perp \mathbf{x}_t \mid \mathbf{x}_0$。[1]因此

$$p_t(c \mid \mathbf{x}_t) = \int p(c \mid \mathbf{x}_0) p(\mathbf{x}_0 \mid \mathbf{x}_t)\, d\mathbf{x}_0.$$

此后验平均一般难以计算，因而免训练方法改为构造任务特定的替代引导方向。第 8.4.1 节的免训练（基于损失的）引导不直接计算 $p_t(c \mid \mathbf{x}_t)$，而使用现成损失 $\ell(\mathbf{x}_t, c; t)$ 衡量当前样本满足条件的程度；损失越小，一致性越好。定义正引导势

$$h_t(\mathbf{x}_t; c) := \exp\big(-\tau \ell(\mathbf{x}_t, c; t)\big), \qquad \tau > 0.$$

低损失样本具有更大的势值。相应引导方向记为

$$\mathbf{G}_t(\mathbf{x}_t, c) := \nabla_{\mathbf{x}_t} \log h_t(\mathbf{x}_t; c) = -\tau \nabla_{\mathbf{x}_t} \ell(\mathbf{x}_t, c; t).$$

分类器引导也自然纳入此图景：总体层面的引导势是 $h_t(\mathbf{x}_t; c) = p_t(c \mid \mathbf{x}_t)$，实践中用学习到的分类器 $p_{\psi^\times}(c \mid \mathbf{x}_t, t)$ 近似。等价地，学习到的分类器对应损失 $\ell(\mathbf{x}_t, c; t) = -\log p_{\psi^\times}(c \mid \mathbf{x}_t, t)$，$\tau = 1$。

在总体层面，以上三种构造共享加性引导模板。给定正势 $h_t(\mathbf{x}_t; c)$ 和引导强度 $w_t \geq 0$，定义

$$\mathbf{s}^{\text{guide}}(\mathbf{x}_t, t, c; w_t) := \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + w_t \mathbf{G}_t(\mathbf{x}_t, c). \tag{8.1.3}$$

基于损失的引导使用 $\mathbf{G}_t = -\tau \nabla_{\mathbf{x}_t} \ell$；精确分类器引导使用 $\mathbf{G}_t = \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t)$；无分类器引导通过条件与无条件得分之差表达相同的总体引导方向。

对每个固定时刻 t，只要可归一化，式 (8.1.3) 就是倾斜密度

$$\widetilde{p}_t^{\text{tilt}}(\mathbf{x}_t \mid c) \propto p_t(\mathbf{x}_t) h_t(\mathbf{x}_t; c)^{w_t}$$

的得分。这给出有用的能量解释：基密度偏好扩散模型所支持的样本，势则将权重转向期望条件。

实践中，将式 (8.1.3) 相应的学习版本或替代版本代入逆时间动力学。上述倾斜密度只是固定时刻解释：$\{\widetilde{p}_t^{\text{tilt}}(\cdot \mid c)\}_t$ 未必等于引导采样器的实际边缘。因此，对一般损失或引导调度，从 T 到 0 积分引导后的 PF-ODE，通常不能得到服从 $\widetilde{p}_0^{\text{tilt}}(\cdot \mid c)$ 的样本。该解释成立所需的跨时间一致性见第 8.4.2 节。

图 8.1 展示引导对采样轨迹的作用。同一原则也可叠加到已有条件模型上，使额外控制信号修改采样动力学。

[1]事实上，$p_t(c \mid \mathbf{x}_t) = \int p(c, \mathbf{x}_0 \mid \mathbf{x}_t) d\mathbf{x}_0 = \int p(c \mid \mathbf{x}_0, \mathbf{x}_t) p(\mathbf{x}_0 \mid \mathbf{x}_t) d\mathbf{x}_0$。标准正向核满足 $p_t(\mathbf{x}_t \mid \mathbf{x}_0, c) = p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，故 $p(c \mid \mathbf{x}_0, \mathbf{x}_t) = p(c \mid \mathbf{x}_0)$，得到下式。

从控制到以直接偏好优化改善对齐。 强控制可以满足条件却不满足偏好：样本可能符合条件信号（如提示词），却偏离人类真正偏好的结果。用偏好评分在 $t=0$ 对条件目标作倾斜：

$$\widetilde{p}_0^{\mathrm{tilt}}(\mathbf{x}_0 \mid c) \propto p_0(\mathbf{x}_0 \mid c) \exp\big(\lambda_{\mathrm{pref}} r(\mathbf{x}_0, c)\big), \qquad \lambda_{\mathrm{pref}} > 0,$$

其中 $r(\mathbf{x}_0, c)$ 是干净样本在条件 c 下的标量对齐评分，越大表示越受偏好，λ_{pref} 控制偏好重加权强度。后面的 KL 正则表述，其优化器以参考策略为基分布，取 $\lambda_{\mathrm{pref}} = 1/\beta$ 后具有此形式。

现有方法通常收集人类对生成结果相对质量的标注，并微调条件扩散模型，常使用基于人类反馈的强化学习（RLHF）。但 RLHF 复杂且常不稳定：先拟合奖励模型捕捉偏好，再以强化学习微调条件模型，在限制其偏离原模型的同时最大化估计奖励。

能否完全去掉奖励模型训练阶段？第 8.5 节用 Diffusion-DPO（Wallace et al., 2024）回答，它将最初为大语言模型提出的直接偏好优化（Rafailov et al., 2023）推广到扩散模型，直接从成对选择学习偏好倾斜，无需单独奖励模型即可使条件模型对齐偏好。

8.2 分类器引导

8.2.1 分类器引导的基础

设 c 为从 $p(c)$ 抽取的条件变量，如类别标签、描述或其他辅助信息，目标是从 $p_0(\mathbf{x} \mid c)$ 采样。扩散条件生成通过运行时间边缘为 $p_t(\cdot \mid c)$ 的逆时间动力学实现这一目标。其漂移依赖条件得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid c)$，$t \in [0, T]$，所以标准有效的途径是估计该量。[2]

Bayes 法则给出

$$\begin{aligned}
\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid c) &= \nabla_{\mathbf{x}_t} \log \left[\frac{p_t(\mathbf{x}_t) p_t(c \mid \mathbf{x}_t)}{p(c)} \right] \\
&= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t) - \nabla_{\mathbf{x}_t} \log p(c) \\
&= \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{无条件得分}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t)}_{\text{分类器梯度}}.
\end{aligned} \tag{8.2.1}$$

这里 $p_t(c \mid \mathbf{x}_t)$ 是给定 $\mathbf{x}_t$ 时 c 的概率，从时刻 t 的含噪输入预测条件。最后一步中，$p(c)$ 不依赖 $\mathbf{x}_t$，故其对数梯度为零。[3]

该分解启发了 Dhariwal and Nichol (2021) 的分类器引导（CG）。为区分总体恒等式和实际学习分类器，先考虑理想量。对 $\omega \geq 0$，在每个固定 t 定义

$$\widetilde{p}_t^{\mathrm{CG},\omega}(\mathbf{x}_t \mid c) \propto p_t(\mathbf{x}_t) p_t(c \mid \mathbf{x}_t)^{\omega}. \tag{8.2.2}$$

其得分为

$$\begin{aligned}
\mathbf{s}^{\mathrm{CG}}(\mathbf{x}_t, t, c; \omega) &:= \nabla_{\mathbf{x}_t} \log \widetilde{p}_t^{\mathrm{CG},\omega}(\mathbf{x}_t \mid c) \\
&= \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + \omega \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t).
\end{aligned} \tag{8.2.3}$$

[2]原则上，若可获得且校准良好的 $p(c \mid \mathbf{x})$，可以通过拒绝采样或重要性采样从无条件生成器得到 $p_0(\mathbf{x} \mid c)$。对高维或罕见条件，这通常不实用。

[3]原文脚注 3 说明：$\nabla_{\mathbf{x}_t} \log p(c) = 0$，因为 $p(c)$ 不依赖 $\mathbf{x}_t$。

因此 ω 缩放分类器引导方向。$\omega = 1$ 时，Bayes 法则给出 $\widetilde{p}_t^{\mathrm{CG},1} = p_t(\cdot \mid c)$，式 (8.2.3) 恢复精确条件得分。一般 ω 下，倾斜密度提供引导场在固定时刻的温度调节解释；它能否构成引导采样器的边缘路径，见第 8.4.2 节。

- $\omega = 1$：恢复真实条件得分；
- $\omega > 1$：放大分类器信号，通常增强条件保真度，往往牺牲多样性；
- $0 \le \omega < 1$：降低分类器信号权重，通常增加样本多样性，但削弱条件化。

CG 的实践近似。 就扩散模型而言，CG 是一种免训练方法，用来引导预训练无条件扩散模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$。CG 只在采样时应用，不修改扩散模型本身。另行训练时变分类器 $p_\psi(c \mid \mathbf{x}_t, t)$，从各噪声水平的含噪输入预测条件，最小化交叉熵

$$\mathbb{E}_{t\sim\mathcal{U}[0,T],\,(\mathbf{x},c)\sim p_{\mathrm{data}},\,\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})}\left[-\log p_\psi(c \mid \mathbf{x}_t, t)\right], \tag{8.2.4}$$

其中 $(\mathbf{x}, c)$ 为带标签配对数据，$\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$。分类器必须跨噪声水平训练，通常以 t 或等价噪声水平表示为输入，才能沿整条扩散路径近似 $p_t(c \mid \mathbf{x}_t)$。训练后，其梯度

$$\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(c \mid \mathbf{x}_t, t) \approx \nabla_{\mathbf{x}_t} \log p_t(c \mid \mathbf{x}_t)$$

替代真实似然梯度。

8.2.2 使用 CG 推断

推断时，将学习分类器梯度乘以 ω 后加入无条件得分估计，得到理想场 (8.2.3) 的学习近似：

$$\begin{aligned}\mathbf{s}_{\mathrm{model}}^{\mathrm{CG}}(\mathbf{x}_t, t, c; \omega) &:= \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)}_{\text{无条件方向}} + \omega \underbrace{\nabla_{\mathbf{x}_t} \log p_{\psi^\times}(c \mid \mathbf{x}_t, t)}_{\text{引导方向}} \\ &\approx \mathbf{s}^{\mathrm{CG}}(\mathbf{x}_t, t, c; \omega).\end{aligned}$$

将逆时间 SDE 或 PF-ODE 中的无条件得分估计替换为此量，就可将生成轨迹引向符合 c 的样本。

8.2.3 优点与局限

CG 机制简单灵活，可用 ω 显式控制条件强度。任意预训练无条件扩散模型都可使用，只需额外分类器。但它存在明显局限：

- **训练成本：**分类器须在全部噪声水平工作，训练成本高；
- **稳健性：**分类器须泛化至严重污染输入，尤其大 t 时，往往有困难；
- **独立训练：**分类器与扩散模型分别训练，可能无法完全吻合模型学得的数据分布。

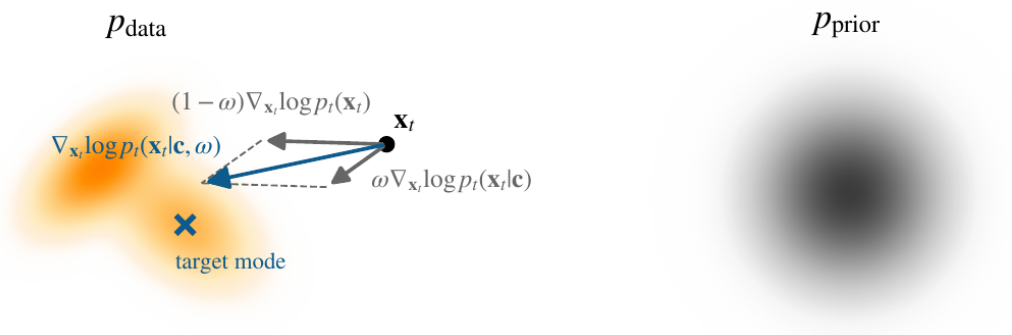


图 8.2: CFG 示意。引导方向是条件得分 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid c)$ 与无条件得分 $\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)$ 的线性组合，由 ω 控制。$0 \le \omega \le 1$ 时在两方向间插值；$\omega > 1$ 时沿条件方向外推，越过条件得分。该场用来将采样轨迹引向条件信号。target mode 表示目标模式；图中数据/先验端与两得分向量沿源图保留。来源：原作者绘制。

8.3 无分类器引导

8.3.1 无分类器引导的基础

无分类器引导（Ho and Salimans, 2021）用条件与无条件得分表示分类器引导方向，免去单独训练分类器。由 Bayes 法则，

$$\nabla_{\mathbf{x}_t}\log p_t(c \mid \mathbf{x}_t) = \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid c) - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t). \tag{8.3.1}$$

代入式 (8.2.3)，得到理想 CFG 场

$$\begin{aligned}\mathbf{s}^{\text{CFG}}(\mathbf{x}_t, t, c; \omega) &:= \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t) + \omega\big(\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid c) - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)\big) \\ &= \omega\underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t \mid c)}_{\text{条件得分}} + (1-\omega)\underbrace{\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t)}_{\text{无条件得分}}.\end{aligned} \tag{8.3.2}$$

得分精确时，此场与式 (8.2.3) 在代数上相同。$\omega = 1$ 时为精确条件得分。其他强度下，固定时刻倾斜密度的解释应与实际动力学产生的边缘区分，见第 8.4.2 节。超参数 $\omega \ge 0$ 控制条件信息影响：

- $\omega = 0$ 时，完全忽略条件，表现为无条件扩散模型；
- $\omega = 1$ 时，使用条件得分，不施加额外引导；
- $\omega > 1$ 时，更强调条件得分、降低无条件得分权重，增强与 c 的对齐，通常降低多样性。

8.3.2 CFG 的训练与采样

通过 CFG 联合训练无条件和条件扩散模型。 CFG 需要模型同时支持条件与无条件预测。它不分别训练两个模型，而使用单个 $\mathbf{s}_\phi(\mathbf{x}_t, t, c)$，训练时随机将条件替换为空标记 $\varnothing$：使用空输入时学习 $\mathbf{s}_\phi(\mathbf{x}_t, t, \varnothing)$，使用原条件时学习 $\mathbf{s}_\phi(\mathbf{x}_t, t, c)$。空条件出现概率为用户指定的条件丢弃概率

算法 3 无条件扩散模型

repeat
  $\mathbf{x} \sim p_{\text{data}}(\mathbf{x})$
  $t \sim \mathcal{U}[0, T]$
  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$
  沿 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t) - \mathbf{s}\|^2$ 做梯度步
until 收敛

算法 4 条件扩散模型的 CFG 训练

Require: p_{uncond}：无条件丢弃概率
repeat
  $(\mathbf{x}, c) \sim p_{\text{data}}(\mathbf{x}, c)$
  以概率 p_{uncond} 令 $c \leftarrow \varnothing$
  $t \sim \mathcal{U}[0, T]$
  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  $\mathbf{x}_t = \alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}$
  沿 $\nabla_\phi \|\mathbf{s}_\phi(\mathbf{x}_t, t, c) - \mathbf{s}\|^2$ 做梯度步
until 收敛

p_{uncond}。算法 3 与 4 并列给出标准无条件训练和 CFG 训练。ω 仅在采样时引入，不属于训练目标。 **译注：**两算法沿用源文未在此重定义的训练目标 $\mathbf{s}$；并不将不可直接访问的边缘得分宣称为监督标签，具体去噪目标以前文 DSM 构造为准。

CFG 条件采样。 用算法 4 训练后，组合得到

$$\begin{aligned}\mathbf{s}^{\text{CFG}}_{\text{model}}(\mathbf{x}_t, t, c; \omega) &:= \omega \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, c)}_{\text{条件得分估计}} + (1-\omega) \underbrace{\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t, \varnothing)}_{\text{无条件得分估计}} \\ &\approx \mathbf{s}^{\text{CFG}}(\mathbf{x}_t, t, c; \omega). \end{aligned} \tag{8.3.3}$$

采样时，用该量替换逆时间 SDE 或 PF-ODE 中的无条件得分估计，从而修改采样场。调整 ω，就能在训练后简单权衡条件强度与样本多样性，无需另行训练分类器或无条件扩散模型。

8.4 免训练引导

免训练引导使用外部条件、损失或测量目标，修改固定预训练扩散模型的采样动力学，不重训扩散模型本身。式 (8.1.1) 的 Bayes 分解给出得分空间中的动机：在无条件得分上加入依赖条件的方向。实践中，任务损失可以修正预测的干净样本，或修正采样时使用的得分。

第 8.4.1 节先介绍两种一般形式；第 8.4.2 节再问，这些替代引导动力学实际生成什么分布；第 8.4.3 节最后介绍逆问题中的代表方法。

设定与记号。 设条件为 c，已知以得分预测表示的预训练模型 $\mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$。[4]另给定任务损失 $\ell(\cdot, c) : \mathbb{R}^D \to \mathbb{R}$ 衡量与期望条件的不一致程度；$\ell(\mathbf{x}, c)$ 越小，符合程度越高。例如，到参考目标的感知距离，或由 CLIP（Radford et al., 2021）等预训练表示给出的特征空间距离或负相似度。

考虑标准线性高斯正向加噪核 $p_t(\cdot \mid \mathbf{x}_0) := \mathcal{N}(\cdot; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$。借用后面式 (9.2.2) 的 DDIM 更新作为具体例子：

$$\mathbf{x}_{t\to t-1} = \alpha_{t-1} \underbrace{\widehat{\mathbf{x}}_0(\mathbf{x}_t)}_{\text{数据空间}} - \sigma_{t-1}\sigma_t \underbrace{\widehat{\mathbf{s}}(\mathbf{x}_t)}_{\text{噪声空间}}, \tag{8.4.1}$$

其中 $\widehat{\mathbf{x}}_0(\mathbf{x}_t) := \mathbf{x}_{\phi^\times}(\mathbf{x}_t, t)$ 是干净 $\mathbf{x}$ 预测，$\widehat{\mathbf{s}}(\mathbf{x}_t) := \mathbf{s}_{\phi^\times}(\mathbf{x}_t, t)$ 是噪声水平 t 的得分预测。

8.4.1 免训练引导的概念框架

常用策略是利用任务损失的梯度，修改预测干净样本或采样更新中的得分项。为区分二者，定义数据空间方向

$$\mathbf{G}_t^{\text{data}}(\mathbf{x}_t, c) := -\nabla_{\mathbf{x}_0} \ell(\mathbf{x}_0, c)\big|_{\mathbf{x}_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)}.$$

噪声空间修正沿用序幕中正势 h_t 的方向 $\mathbf{G}_t(\mathbf{x}_t, c) := \nabla_{\mathbf{x}_t} \log h_t(\mathbf{x}_t; c)$，具体势将在下文给出。利用式 (8.4.1)，两种修正可写为

$$\begin{aligned}\mathbf{x}_{t\to t-1} = \alpha_{t-1} &\underbrace{\Big(\widehat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}} \mathbf{G}_t^{\text{data}}(\mathbf{x}_t, c)\Big)}_{\text{A：数据空间}} \\ &- \sigma_{t-1}\sigma_t \underbrace{\Big(\widehat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}} \mathbf{G}_t(\mathbf{x}_t, c)\Big)}_{\text{B：噪声空间}},\end{aligned} \tag{8.4.2}$$

其中 $\eta_t^{\text{data}}, \eta_t^{\text{latent}} \geq 0$ 分别控制数据空间与噪声空间修正强度。

A：数据空间中的引导。 以局部降低任务损失的一步直接改进当前干净估计：

$$\widehat{\mathbf{x}}_0(\mathbf{x}_t) \longmapsto \widehat{\mathbf{x}}_0(\mathbf{x}_t) + \eta_t^{\text{data}} \mathbf{G}_t^{\text{data}}(\mathbf{x}_t, c).$$

先将干净预测移向更符合条件的方向，再用于后续采样更新。如需多步优化，也可重复此修正。代表包括 MGPD（He et al., 2023）与 UGD（Bansal et al., 2023）。

B：噪声空间中的引导。 另一种密切相关的策略直接引导采样使用的得分。依照第 8.1 节的势视角，在当前去噪估计上计算损失，并取

$$\begin{aligned} h_t(\mathbf{x}_t; c) &:= \exp\left[-\tau \ell\big(\widehat{\mathbf{x}}_0(\mathbf{x}_t), c\big)\right], \qquad \tau > 0, \\ \mathbf{G}_t(\mathbf{x}_t, c) &= \nabla_{\mathbf{x}_t} \log h_t(\mathbf{x}_t; c) = -\tau \nabla_{\mathbf{x}_t} \ell\big(\widehat{\mathbf{x}}_0(\mathbf{x}_t), c\big). \end{aligned}$$

式 (8.4.2) 中的得分项变为 $\widehat{\mathbf{s}}(\mathbf{x}_t) + \eta_t^{\text{latent}} \mathbf{G}_t(\mathbf{x}_t, c)$。与总体构造 (8.1.3) 相比，$\eta_t^{\text{latent}}$ 充当一般引导强度 w_t，而 $\widehat{\mathbf{s}}$ 用学习估计替代精确无条件得分。

[4]为简单起见，此处使用得分和 $\mathbf{x}$ 预测参数化；$\boldsymbol{\epsilon}$ 预测等其他参数化可类似处理。

若 $h_t(\mathbf{x}_t; c)$ 与真实条件似然 $p_t(c \mid \mathbf{x}_t)$ 仅差一个不依赖 $\mathbf{x}_t$ 的因子，则 $\mathbf{G}_t$ 恢复 Bayes 引导方向。对一般任务损失，$\mathbf{G}_t$ 定义替代引导方向。计算它需要对 $\mathbf{x}$ 预测求导：

$$\mathbf{G}_t(\mathbf{x}_t, c) = -\tau[\nabla_{\mathbf{x}_t} \widehat{\mathbf{x}}_0(\mathbf{x}_t)]^\top \nabla_{\mathbf{x}_0} \ell(\mathbf{x}_0, c)|_{\mathbf{x}_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)},$$

实践中成本可能很高。代表包括 Yu et al. (2023)、Chung et al. (2022) 与 Bansal et al. (2023)。以上仅规定每个采样步如何修改；它们本身不决定跨全部噪声水平积分后得到的边缘分布，下面澄清此区别。

8.4.2 引导采样产生什么分布？

上述势视角在总体层面有精确的固定时刻密度解释。将学习到的无条件得分 $\widehat{\mathbf{s}}$ 替换为精确得分，正势 $h_t(\mathbf{x}; c)$ 与强度 $w_t \geq 0$ 定义理想引导场

$$\nabla_{\mathbf{x}} \log p_t(\mathbf{x}) + w_t \nabla_{\mathbf{x}} \log h_t(\mathbf{x}; c).$$

对固定 t，这是下式的得分：

$$\widetilde{p}_t^{\text{tilt}}(\mathbf{x} \mid c) = \frac{1}{Z_t(c)} p_t(\mathbf{x}) h_t(\mathbf{x}; c)^{w_t},$$
$$Z_t(c) = \int p_t(\mathbf{x}) h_t(\mathbf{x}; c)^{w_t} \, d\mathbf{x}, \tag{8.4.3}$$

条件是 $0 < Z_t(c) < \infty$。实践中的学习场通过估计 $\widehat{\mathbf{s}}$ 近似这一理想构造。对上面的损失构造，$h_t(\mathbf{x}_t; c) = \exp[-\tau \ell(\widehat{\mathbf{x}}_0(\mathbf{x}_t), c)]$，而 η_t^{latent} 对应 w_t。

固定时刻恒等式不决定沿噪声水平积分后生成的分布。因此，一般损失和引导调度下，从 T 到 0 求解引导 PF-ODE，通常并不产生 $\widetilde{p}_0^{\text{tilt}}$ 分布的样本。原因是跨时间一致性：不同噪声水平的密度不能独立选取。若 $\{\widetilde{p}_t^{\text{tilt}}\}_t$ 要成为同一正向扩散的边缘路径，还须满足相应 Fokker–Planck 方程：

$$\partial_t \widetilde{p}_t^{\text{tilt}} + \nabla_{\mathbf{x}} \cdot \big(f(t)\mathbf{x} \widetilde{p}_t^{\text{tilt}}\big) - \frac{1}{2} g^2(t) \Delta_{\mathbf{x}} \widetilde{p}_t^{\text{tilt}} = 0.$$

若此条件成立，则对应 PF-ODE

$$\frac{d\mathbf{x}(t)}{dt} = f(t)\mathbf{x}(t) - \frac{1}{2} g^2(t) \nabla_{\mathbf{x}} \log \widetilde{p}_t^{\text{tilt}}(\mathbf{x}(t) \mid c)$$

从相应终端分布 $\widetilde{p}_T^{\text{tilt}}(\cdot \mid c)$ 初始化后，以 $\widetilde{p}_t^{\text{tilt}}$ 为边缘路径。

可直接检验相容条件。将式 (8.4.3) 代入 Fokker–Planck 方程，利用 p_t 本身满足同一方程，可得

$$\begin{aligned}
&\partial_t \widetilde{p}_t^{\text{tilt}} + \nabla_{\mathbf{x}} \cdot \big(f(t)\mathbf{x} \widetilde{p}_t^{\text{tilt}}\big) - \frac{1}{2} g^2(t) \Delta_{\mathbf{x}} \widetilde{p}_t^{\text{tilt}} \\
&\quad = \widetilde{p}_t^{\text{tilt}} \Big[\partial_t \log h_t^{w_t} + f(t)\mathbf{x} \cdot \nabla_{\mathbf{x}} \log h_t^{w_t} - g^2(t) \nabla_{\mathbf{x}} \log p_t \cdot \nabla_{\mathbf{x}} \log h_t^{w_t} \\
&\qquad\qquad - \tfrac{1}{2} g^2(t) \big(\Delta_{\mathbf{x}} \log h_t^{w_t} + \|\nabla_{\mathbf{x}} \log h_t^{w_t}\|^2 \big) - Z_t'/Z_t \Big],
\end{aligned}$$

为易读省略自变量 $(\mathbf{x}; c)$。倾斜族只有在方括号为零时才是有效边缘路径。一般任务损失和调度未必满足它；即使得分计算与 ODE 积分精确，仍可能存在不匹配。它来自引导动力学自身，而非数值离散误差。这是 Lai et al. (2023a) 所讨论的更一般 Fokker–Planck 一致性要求的例子。

两个简单情形说明区别。$w_t \equiv 0$ 时，倾斜消失，恢复无条件路径 p_t。精确分类器引导中，若正向扩散仅污染 $\mathbf{x}$ 而保持 c 固定，取 $h_t(\mathbf{x}; c) = p_t(c \mid \mathbf{x})$、$w_t \equiv 1$，由 Bayes 法则得 $\widetilde{p}_t^{\mathrm{tilt}}(\mathbf{x} \mid c) = p_t(\mathbf{x} \mid c)$，恰为条件边缘路径。这解释了理想分类器似然下引导权重 1 的特殊性。

一般强度下，如 $p_t(\mathbf{x})p_t(c \mid \mathbf{x})^{\omega}$，只要可归一化，它仍定义有效的固定时刻倾斜密度，却通常不能保证描述引导采样器的边缘。特殊选择可能满足相容条件，所以仅有 $\omega \neq 1$ 并不意味着不一致。

若目标是更忠实地跟踪指定倾斜分布序列，Feynman–Kac Correctors（原引文键 `skreta2025feynman`）等修正方法会显式处理跨时间不匹配。[5]

8.4.3 逆问题中免训练方法的例子

第 8.4.1 节原则在逆问题中有重要应用。先介绍背景，再给出使用预训练扩散模型、在推断时解决逆问题的具体例子。

逆问题背景。 设 $\mathcal{A}$ 为已知、可能非线性的正向算子，且

$$\mathbf{y} = \mathcal{A}(\mathbf{x}_0) + \sigma_y \mathbf{z}, \qquad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \tag{8.4.4}$$

Bayes 目标是刻画后验 $p_0(\mathbf{x}_0 \mid \mathbf{y})$，将测量模型与合理干净信号的先验知识结合。盲逆问题进一步把 $\mathcal{A}$ 的未知参数作为待推断量。

经典方法常在变分或 Bayes 框架中结合数据保真项与解析或手工先验。监督恢复则可从配对数据学习测量到干净信号的直接映射。预训练扩散提供第三条路线：干净数据的学习先验可跨测量算子复用，测量信息只在推断时引入。

预训练扩散模型作为逆问题求解器。 由 Bayes 法则，

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{y}) = \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}_{\text{数据得分}} + \underbrace{\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y} \mid \mathbf{x}_t)}_{\text{测量引导}}. \tag{8.4.5}$$

数据得分可由预训练模型提供，而测量项一般无闭式解。免训练逆求解器在采样时引入测量信息，但数学形式不必相同。一类通过修改或投影中间样本直接实施测量一致性；另一类近似似然得分 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y} \mid \mathbf{x}_t)$，再按式 (8.4.5) 加入数据得分。

ILVR（Choi et al., 2021）。 这是第一种策略的简单例子。设 φ_N 为其线性低通算子，每个逆向步骤先生成无条件提议，再将参考图像加噪至相同水平：

$$\mathbf{x}'_{t-1} \sim p_\theta(\mathbf{x}'_{t-1} \mid \mathbf{x}_t),$$
$$\mathbf{y}_{t-1} \sim p_{t-1}(\mathbf{y}_{t-1} \mid \mathbf{y}).$$

随后修正为

$$\mathbf{x}_{t-1} = \varphi_N(\mathbf{y}_{t-1}) + (\mathbf{I} - \varphi_N)\mathbf{x}'_{t-1}.$$

指定低频分量来自加噪参考，互补分量来自无条件提议。这是样本空间的一致性修正，而非对似然得分的显式近似。

[5]译注：冻结源此处直接显示引文键，未静默补造成作者年份；完整文献后续按源书目核对。

扩散后验采样（DPS；Chung et al., 2022）。 对已知非线性算子 $\mathcal{A}$、加性高斯测量噪声 $\sigma_y > 0$，DPS 近似

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y} \mid \mathbf{x}_t) \approx \nabla_{\mathbf{x}_t} \log p\big(\mathbf{y} \mid \mathbf{X}_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)\big). \tag{8.4.6}$$

其中 $\widehat{\mathbf{x}}_0(\mathbf{x}_t) := \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$ 是干净样本的后验均值。通常使用预训练模型，并由 Tweedie 公式（式 (3.3.6)）估计该均值。

插件近似以测量似然在后验均值处的值，替换其后验平均：

$$\begin{aligned} p_t(\mathbf{y} \mid \mathbf{x}_t) &= \int p_t(\mathbf{y} \mid \mathbf{x}_t, \mathbf{x}_0) p(\mathbf{x}_0 \mid \mathbf{x}_t)\, d\mathbf{x}_0 \\ &= \int p_t(\mathbf{y} \mid \mathbf{x}_0) p(\mathbf{x}_0 \mid \mathbf{x}_t)\, d\mathbf{x}_0 \approx p_t\big(\mathbf{y} \mid \mathbf{X}_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)\big). \end{aligned}$$

这里用了给定 $\mathbf{x}_0$ 后 $\mathbf{y}$ 只依赖 $\mathbf{x}_0$ 而不依赖 $\mathbf{x}_t$；近似以 $p(\mathbf{x}_0 \mid \mathbf{x}_t)$ 在均值附近高度集中为假设。

由于 $p_t(\mathbf{y} \mid \mathbf{X}_0 = \widehat{\mathbf{x}}_0(\mathbf{x}_t)) = \mathcal{N}(\mathbf{y}; \mathcal{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)), \sigma_y^2 \mathbf{I})$，可得

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log p_t(\mathbf{y} \mid \mathbf{x}_t) &\approx \nabla_{\mathbf{x}_t} \log \mathcal{N}\big(\mathbf{y}; \mathcal{A}(\widehat{\mathbf{x}}_0), \sigma_y^2 \mathbf{I}\big) \\ &= -\frac{1}{2\sigma_y^2} \nabla_{\mathbf{x}_t} \|\mathbf{y} - \mathcal{A}(\widehat{\mathbf{x}}_0)\|^2 \\ &= \frac{1}{\sigma_y^2} \big[\mathbf{J}_{\mathcal{A}}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)) \cdot \nabla_{\mathbf{x}_t} \widehat{\mathbf{x}}_0(\mathbf{x}_t)\big]^\top \big(\mathbf{y} - \mathcal{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t))\big), \end{aligned}$$

其中 $\mathbf{J}_{\mathcal{A}}(\widehat{\mathbf{x}}_0(\mathbf{x}_t)) := \nabla_{\mathbf{x}_0} \mathcal{A}(\mathbf{x})|_{\mathbf{x}=\widehat{\mathbf{x}}_0(\mathbf{x}_t)}$ 是正向算子关于输入的 Jacobian。此式沿得分近似链路传播梯度，反映测量似然如何随含噪样本的扰动变化。线性逆问题进一步简化为

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{y} \mid \mathbf{x}_t) \approx \frac{1}{\sigma_y^2} [\mathbf{A} \cdot \nabla_{\mathbf{x}_t} \widehat{\mathbf{x}}_0(\mathbf{x}_t)]^\top \big(\mathbf{y} - \mathbf{A}(\widehat{\mathbf{x}}_0(\mathbf{x}_t))\big).$$

大量工作通过不同似然得分近似探索扩散逆问题求解器，综述见 Daras et al. (2024)。

相关的监督迭代恢复视角及其与 PF-ODE 的联系。 以上通过 Bayes 得分分解将预训练扩散先验与测量模型结合。同时，它们也体现更广泛的思想：不一步恢复干净信号，而用多次小更新逐渐改善污染输入。监督图像恢复也有类似高层策略，但它从污染与干净配对样本直接学习细化过程，不把预训练得分模型作为先验。

代表是 InDI（原引文键 `delbracio2023inversion`）。它从配对数据 $(\mathbf{y}, \mathbf{x}_0)$ 出发，$\mathbf{y}$ 为污染观测，$\mathbf{x}_0$ 为相应干净目标；一般并不假定污染过程解析已知或为高斯。用插值路径连接两端点：

$$\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{y}, \qquad t \in [0, 1].$$

这只是从干净目标到污染观测的方便轨迹，一般不是高斯加噪过程。沿此路径，对任意 $0 \le s \le t$，有精确关系

$$\begin{aligned} \mathbf{x}_s &= \left(1 - \frac{s}{t}\right) \mathbf{x}_0 + \frac{s}{t} \mathbf{x}_t, \\ \mathbb{E}[\mathbf{x}_s \mid \mathbf{x}_t] &= \left(1 - \frac{s}{t}\right) \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t] + \frac{s}{t} \mathbf{x}_t. \end{aligned}$$

第二式由给定 $\mathbf{x}_t$ 的条件期望得到。因此，从当前状态移至略轻度退化的状态，只需从 $\mathbf{x}_t$ 预测干净目标。[6]

据此，用配对样本训练时间条件预测器 $F_\phi(\mathbf{x}_t, t)$，最小化

$$\min_{\phi} \ \mathbb{E}_{(\mathbf{x}_0,\mathbf{y})\sim p(\mathbf{x}_0,\mathbf{y}),\, t\sim p(t)} \left\| F_\phi\big((1-t)\mathbf{x}_0 + t\mathbf{y}, t\big) - \mathbf{x}_0 \right\|_2^2 .$$

$p(\mathbf{x}_0, \mathbf{y})$ 为配对数据联合分布，$p(t)$ 指定训练插值时间的抽取方式。也就是从路径上的中间退化状态预测干净目标。平方误差的 Bayes 最优预测器为 $F^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$。若模型足够有表达力、优化成功，学习预测器近似时间 t 中间状态所对应的平均干净目标。这与扩散训练精神相近：都学习从中间污染状态到较干净目标的时间条件回归。区别是扩散模型由指定正向污染过程合成训练对，此处端点对直接来自监督恢复数据。

推断从 $\widehat{\mathbf{x}}_1 = \mathbf{y}$ 开始，重复

$$\widehat{\mathbf{x}}_{t-\Delta t} = \frac{\Delta t}{t} F_\phi(\widehat{\mathbf{x}}_t, t) + \left(1 - \frac{\Delta t}{t}\right) \widehat{\mathbf{x}}_t.$$

最终重建由逐渐细化而非单次预测得到。连续时间极限给出 InDI 剩余流 ODE

$$\frac{d\mathbf{x}_t}{dt} = \frac{\mathbf{x}_t - F_\phi(\mathbf{x}_t, t)}{t}.$$

再专门考虑高斯去噪，假定污染具有已知解析形式 $\mathbf{y} = \mathbf{x}_0 + \sigma\boldsymbol{\epsilon}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，噪声水平 σ 已知。此时插值路径

$$\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{y} = \mathbf{x}_0 + t\sigma\boldsymbol{\epsilon} = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}, \qquad \alpha_t = 1, \quad \sigma_t = t\sigma$$

恰为标准扩散形式，InDI 剩余流 ODE 恰好化为概率流 ODE。因为此时 $F_\phi \approx \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$ 学习去除高斯污染，且 Tweedie 公式给出

$$\begin{aligned} \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t] &= \mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t), \\ \frac{d\mathbf{x}_t}{dt} &= \frac{\mathbf{x}_t - \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]}{t} = -\dot{\sigma}_t \sigma_t \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t). \end{aligned}$$

最后一步使用 $\sigma_t = t\sigma$。这是高斯去噪路径的 PF-ODE，既可写为去噪器形式，也可写为得分形式。因此，高斯去噪特例下，InDI 提供扩散建模的另一解释：把它看作高斯污染数据上的监督去噪器学习，PF-ODE 则是逐渐细化的连续时间极限。[7]

8.5 从强化学习到用于模型对齐的直接偏好优化

使生成模型与人类意图对齐时，主流范式是基于人类反馈的强化学习（RLHF）。它虽有效，却是复杂、多阶段且可能不稳定的过程。本节介绍直接偏好优化（DPO；Rafailov et al., 2023），无需显式奖励建模或强化学习，就以更简洁、稳定的方式追求同一目标。随后概述经 Diffusion-DPO（Wallace et al., 2024）对扩散模型的推广。

[6]译注：源文范围写 $0 \le s \le t$，含比值的公式按其表达仅在 $t > 0$ 有定义；$t = 0$ 须另取端点解释，未静默添加一般极限结论。

[7]译注：此处等号中的条件均值对应理想 Bayes 预测器；有限网络 F_ϕ 仅近似它，不能由训练回归形式推出精确 PF-ODE。

8.5.1 动机：绕开 RLHF 的困难

对齐旨在引导预训练基模型（如 SFT 模型）产生人类更偏好的输出。RLHF 分三阶段：监督微调（SFT）在提示–响应对上训练基模型；奖励建模（RM）利用包含提示 c 与成对响应（偏好的赢家 $\mathbf{x}_w$ 和不受偏好的输家 $\mathbf{x}_l$）的数据，学习满足 $r(c,\mathbf{x}_w) > r(c,\mathbf{x}_l)$ 的标量评分；最后用 PPO（Schulman et al., 2017）等算法对 SFT 策略 π[8]作强化学习微调，在最大化 r 期望奖励的同时，用 KL 惩罚使策略接近参考/SFT 分布。

这一流程虽有影响，也有缺点：RL 阶段是同策略的，每次更新都需当前模型新生成样本，成本高且不稳定；还需训练、托管多个大模型（SFT、奖励，有时还有价值模型）；它只优化人类偏好的代理，奖励模型的缺陷可能被利用。这引出核心问题：

问题 8.5.1. *能否去掉显式奖励建模与不稳定的 RL 步骤，直接在偏好数据上优化模型？*

DPO 以单个类似监督学习的步骤替代多阶段 RLHF。无需训练独立奖励模型或运行 PPO，而是以简单 logistic 损失拟合偏好对，同时接近固定参考模型。关键是重写 KL 正则 RLHF 目标，使策略与参考的对数似然比成为隐式奖励：保留朝向参考的正则化，避免昂贵的策略采样和显式奖励建模。

第 8.5.2 小节回顾 RLHF 和大模型奖励/RL 微调，第 8.5.3 小节给出最初用于语言模型的 DPO，第 8.5.4 小节将其扩展到扩散生成模型。

8.5.2 RLHF：Bradley–Terry 视角

RLHF 简介。 RLHF 从学习一个评判者开始：奖励模型 r_ψ 对同一提示 c 的候选响应赋标量偏好分数。数据集 $\mathcal{D}$ 包含响应对 $(\widetilde{\mathbf{x}},\mathbf{x})$ 及标签 y，表示前者是否优于后者。y 可为二元值 $\{0,1\}$，也可为汇总多名评分者后得到的软值 $[0,1]$。训练目标是 logistic 损失

$$\mathcal{L}_{\mathrm{RM}}(\psi) = -\mathbb{E}_{(c,\widetilde{\mathbf{x}},\mathbf{x},y)\sim\mathcal{D}}\Big[y\log\sigma\big(r_\psi(c,\widetilde{\mathbf{x}}) - r_\psi(c,\mathbf{x})\big) + (1-y)\log\big(1-\sigma(r_\psi(c,\widetilde{\mathbf{x}}) - r_\psi(c,\mathbf{x}))\big)\Big], \tag{8.5.1}$$

其中 $\sigma(u) = 1/(1+e^{-u})$。偏好对可来自人工整理响应、不同检查点模型快照，或预训练条件扩散模型的生成结果。通常按（赢家、输家）存储。此时令 $y=1$、$\widetilde{\mathbf{x}} = \mathbf{x}_w$、$\mathbf{x} = \mathbf{x}_l$，得到

$$\mathcal{L}_{\mathrm{RM}}(\psi) = -\mathbb{E}_{(c,\mathbf{x}_w,\mathbf{x}_l)\sim\mathcal{D}}\left[\log\sigma\big(r_\psi(c,\mathbf{x}_w) - r_\psi(c,\mathbf{x}_l)\big)\right]. \tag{8.5.2}$$

Bradley–Terry 视角及 KL 联系。 按照 Bradley–Terry（BT）模型（Bradley and Terry, 1952），将两个标量评分转换为获胜概率：

$$p_{r_\psi}(\widetilde{\mathbf{x}} \succ \mathbf{x} \mid c) := \sigma\big(r_\psi(c,\widetilde{\mathbf{x}}) - r_\psi(c,\mathbf{x})\big).$$

这表明只有评分差有意义，$r_\psi(c,\cdot)$ 对平移不变；损失推动预测赢家评分高于输家。为直观理解，考虑 $y\in\{0,1\}$ 的单对，记

$$\Delta r := r_\psi(c,\widetilde{\mathbf{x}}) - r_\psi(c,\mathbf{x}), \qquad p := \sigma(\Delta r), \qquad \sigma(u) = \frac{1}{1+e^{-u}},$$
$$\ell = -[y\log p + (1-y)\log(1-p)].$$

[8]策略将提示或历史（状态）映射为响应或动作的分布。

则 $\partial \ell / \partial \Delta r = \sigma(\Delta r) - y$，用步长 $\eta > 0$ 梯度下降时，评分间隔更新为

$$\Delta r \leftarrow \Delta r - \eta\big(\sigma(\Delta r) - y\big).$$

若 $y = 1$（$\tilde{\mathbf{x}}$ 获胜），$\sigma(\Delta r) - 1 \le 0$，间隔增大（赢家向上、输家向下）；若 $y = 0$，间隔减小。

式 (8.5.1) 每个样本项都是观测 Bernoulli 标签与预测获胜概率的交叉熵：

$$\begin{aligned} -[y \log p_{r_\psi} + (1-y)\log(1 - p_{r_\psi})] = D_{\mathrm{KL}}\big(\mathrm{Bern}(y) \,\|\, \mathrm{Bern}(p_{r_\psi})\big) \\ + H\big(\mathrm{Bern}(y)\big), \end{aligned}$$

H 为目标 Bernoulli 分布的熵。对数据平均得

$$\begin{aligned} \mathcal{L}_{\mathrm{RM}}(\psi) = \mathbb{E}_{\mathcal{D}}\left[D_{\mathrm{KL}}\big(\mathrm{Bern}(y) \,\|\, \mathrm{Bern}(p_{r_\psi})\big)\right] \\ + \underbrace{\mathbb{E}_{\mathcal{D}}\left[H(\mathrm{Bern}(y))\right]}_{\text{与}\psi\text{ 无关}}. \end{aligned} \tag{8.5.3}$$

所以最小化 logistic 损失等价于最小化人类标签经验 Bernoulli 分布与模型预测 Bernoulli 分布之间的 KL 散度。二元标签时二者数值相等；软标签时相差熵常数。直观上，奖励模型调整获胜概率，使其符合数据中观测到的人类经验胜率。

以下采用最常见的有序格式 $(\mathbf{x}_w, \mathbf{x}_l, c) \sim \mathcal{D}$，标签恒为 1，使用式 (8.5.2)。

固定奖励下的 KL 正则策略优化。 由式 (8.5.2) 拟合奖励 $r := r_{\psi^\times}$ 后，以条件预训练扩散模型 $p_{\phi^\times}(\mathbf{x} \mid c)$ 为基础，RLHF 调整可学习策略 $\pi_\theta(\mathbf{x} \mid c)$，通常从该模型微调，趋向高奖励响应。同时，用 KL 惩罚使策略接近参考 $\pi_{\mathrm{ref}}(\mathbf{x} \mid c) := p_{\phi^\times}(\mathbf{x} \mid c)$：

$$\max_\theta \ \mathbb{E}_{c \sim p(c)}\left[\mathbb{E}_{\mathbf{x} \sim \pi_\theta(\cdot|c)}[r_\psi(c, \mathbf{x})] - \beta D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid c) \| \pi_{\mathrm{ref}}(\cdot \mid c)\big)\right]. \tag{8.5.4}$$

此式显式体现两股作用：寻找评判者更偏好的样本，同时接近预训练参考。奖励目标 (8.5.2) 只使用带标签对，不要求数据由参考（预训练条件扩散）模型生成。不过，从接近目标策略的模型收集数据，可能减少分布偏移，使奖励在实际使用区域更可靠。

因此 RLHF 先最小化式 (8.5.2)（等价地，式 (8.5.3) 的期望二元 KL）拟合 r^*，再解式 (8.5.4) 优化 π^*。

8.5.3 DPO 框架

从 RLHF 搭起桥梁。 给定拟合奖励 $r := r_{\psi^\times}$，对每个提示 c，式 (8.5.4) 的 KL 正则策略目标具有能量形式闭式解（Peters et al., 2010）：

$$\pi^*(\mathbf{x} \mid c) = \frac{1}{Z(c)} \pi_{\mathrm{ref}}(\mathbf{x} \mid c) \exp\big(r(c, \mathbf{x})/\beta\big), \tag{8.5.5}$$

其中 $\pi_{\mathrm{ref}} := p_{\phi^\times}$，配分函数 $Z(c)$ 确保积分为 1。[9]

较小 β 使 $\exp(r/\beta)$ 更尖锐，π^* 集中于高奖励区域：奖励主导，策略远离参考，多样性下降，训练可能不稳定或出现奖励投机。较大 β 使倾斜变平，KL 主导、更新保守，策略更接近参考、多样性随参考而定，但奖励提升有限。

为直接微调策略而不训练独立奖励模型，可反转式 (8.5.5)，从任意策略定义隐式奖励。

[9]译注：闭式分布结论要求 $\beta > 0$、归一化常数有限非零及相应绝对连续性；这是分布空间优化器，受限参数模型未必能精确实现它。

由反转最优策略式定义隐式奖励。 对任意支撑包含于 π_{ref} 的策略 π，定义

$$r_\pi(c,\mathbf{x}) = \beta \log \frac{\pi(\mathbf{x} \mid c)}{\pi_{\text{ref}}(\mathbf{x} \mid c)} + \beta \log Z(c). \tag{8.5.6}$$

那么式 (8.5.5) 中以 π 替代 π^* 仍成立：π 是奖励 r_π 下式 (8.5.4) 的优化器。该策略诱导隐式奖励只确定到依赖提示的常数 $\beta \log Z(c)$，但常数在 BT 等成对比较中消去：

$$r_\pi(c,\mathbf{x}_w) - r_\pi(c,\mathbf{x}_l) = \beta \left(\log \frac{\pi(\mathbf{x}_w \mid c)}{\pi_{\text{ref}}(\mathbf{x}_w \mid c)} - \log \frac{\pi(\mathbf{x}_l \mid c)}{\pi_{\text{ref}}(\mathbf{x}_l \mid c)} \right).$$

这使常数与偏好学习无关，并直接导出基于对数概率差的 DPO 损失。

DPO 训练损失。 将式 (8.5.6) 代入同一提示下有序对 $(\mathbf{x}_w, \mathbf{x}_l)$ 的 BT 损失 (8.5.2)，常数消去：

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(c,\mathbf{x}_w,\mathbf{x}_l)\sim\mathcal{D}} \left[\log \sigma \left(\beta \left[\log \frac{\pi_\theta(\mathbf{x}_w \mid c)}{\pi_{\text{ref}}(\mathbf{x}_w \mid c)} - \log \frac{\pi_\theta(\mathbf{x}_l \mid c)}{\pi_{\text{ref}}(\mathbf{x}_l \mid c)} \right] \right) \right].$$

也就是提高赢家相对输家的、经温度缩放的优势：它以相对参考模型的对数似然改善之差衡量，形式为 $-\log \sigma\big(\beta[\pi_\theta/\pi_{\text{ref}} \text{ 在赢家与输家处的对数比之差}]\big)$。由此在单次稳定的分类式微调中追求 RLHF 目标，无需显式奖励模型。

8.5.4 Diffusion-DPO

本小节沿用第 8.5.3 节策略记号：π_θ 和 π_{ref} 指学习与参考扩散策略，包括路径及转移分布；$p_t(\mathbf{x}_t \mid \mathbf{x}_0)$ 仍指固定正向加噪过程。

为什么朴素 DPO 不适用于扩散模型？ 计算样本似然 $\pi_\theta(\mathbf{x} \mid c)$ 需要 ODE 求解的瞬时换元公式（漂移散度；式 (4.3.7)），成本很高；[10]对整条采样轨迹求导还可能梯度消失或爆炸。Diffusion-DPO 因而在路径层面工作。以下用 DDPM 等离散时间模型说明，连续时间情形类似。

定义路径隐式奖励。 逆时间 Markov 链的轨迹记为 $\mathbf{x}_{0:T} := (\mathbf{x}_T, \ldots, \mathbf{x}_0)$，转移为 $\pi(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)$；$\mathbf{x}_T$ 是最高噪声状态，$\mathbf{x}_0$ 为干净输出。

人类偏好由最终输出的 $r(c,\mathbf{x}_0)$ 定义。因为每条轨迹均含 $\mathbf{x}_0$，转到路径空间不需要改变奖励本身，而是对整个逆过程正则化。KL 链式法则表明，完整路径间 KL 不小于端点边缘间 KL，因而考虑

$$\max_\theta \ \mathbb{E}_{c\sim p(c)} \left[\mathbb{E}_{\mathbf{x}_{0:T}\sim\pi_\theta(\cdot|c)}[r(c,\mathbf{x}_0)] - \beta D_{\text{KL}}\big(\pi_\theta(\cdot \mid c) \| \pi_{\text{ref}}(\cdot \mid c)\big) \right],$$

其中两 π 是相应路径分布。奖励项不变，KL 还控制潜在去噪轨迹偏离参考的程度。分布层面若归一化常数有限，每个提示的优化器为

$$\pi^*(\mathbf{x}_{0:T} \mid c) = \frac{1}{Z(c)} \pi_{\text{ref}}(\mathbf{x}_{0:T} \mid c) \exp\big(r(c,\mathbf{x}_0)/\beta\big). \tag{8.5.7}$$

类似普通 DPO，反转定义任意策略诱导的路径奖励

$$R_\pi(c,\mathbf{x}_{0:T}) := \beta \log \frac{\pi(\mathbf{x}_{0:T} \mid c)}{\pi_{\text{ref}}(\mathbf{x}_{0:T} \mid c)} + \beta \log Z(c).$$

最优时 $R_{\pi^*} = r(c,\mathbf{x}_0)$；一般策略的 R_π 也可能依赖潜轨迹。偏好数据只比较干净端点，因此对每个端点对应轨迹上的隐式奖励求平均。

[10]离散时间扩散模型（如 DDPM）计算 $\pi_\theta(\mathbf{x}_0 \mid c)$ 需要对潜逆向轨迹 $\mathbf{x}_{1:T}$ 边缘化。

从路径隐式奖励到 DPO。 同提示下端点对 $(\mathbf{x}_0^w, \mathbf{x}_0^l)$，BT 间隔由隐式路径奖励的条件平均之差给出：

$$\begin{aligned}\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}}) &:= -\mathbb{E}_{(c,\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}}\left[\log\sigma\big(\Delta R(c;\theta)\big)\right],\\ \Delta R(c;\theta) &:= \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^w\sim\pi_\theta(\cdot|\mathbf{x}_0^w,c)}\left[R_{\pi_\theta}\big(c,(\mathbf{x}_0^w,\mathbf{x}_{1:T}^w)\big)\right]}_{\text{赢家路径期望}}\\ &\quad - \underbrace{\mathbb{E}_{\mathbf{x}_{1:T}^l\sim\pi_\theta(\cdot|\mathbf{x}_0^l,c)}\left[R_{\pi_\theta}\big(c,(\mathbf{x}_0^l,\mathbf{x}_{1:T}^l)\big)\right]}_{\text{输家路径期望}}.\end{aligned} \tag{8.5.8}$$

此处条件期望意为：固定数据集中的端点（如赢家），在模型诱导的条件路径分布（逆时间轨迹后验）上平均；这些轨迹通过核 $\pi_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t,c)$ 可能产生此端点。中间状态不可观测，所以对所有这类轨迹平均路径奖励。

式 (8.5.8) 有三个现实困难：

1. **端点条件化诱导难解的路径后验。**$\mathbb{E}_{\pi_\theta(\mathbf{x}_{1:T}|\mathbf{x}_0,c)}$ 对必须命中端点的逆路径平均，而采样器运行无此约束的 $\mathbf{x}_T\to\cdots\to\mathbf{x}_0$。端点条件形成一般无闭式、采样昂贵的扩散桥后验。

2. **嵌套、与 θ 耦合的期望。**损失 $-\log\sigma(\Delta R)$ 中，$\Delta R=\mathbb{E}_{\text{paths}|\mathbf{x}_0^w,c}[R_{\pi_\theta}]-\mathbb{E}_{\text{paths}|\mathbf{x}_0^l,c}[R_{\pi_\theta}]$ 的路径联合分布与被积量都依赖 θ，因此梯度必须穿过采样分布，形成 REINFORCE 或路径导数耦合，方差很高。

3. **长链、大求和与昂贵反传。**计算 R_{π_θ} 中 $\beta[\log\pi_\theta(\mathbf{x}_{0:T}\mid c)-\log\pi_{\text{ref}}(\mathbf{x}_{0:T}\mid c)]$，对策略与参考、赢家与输家都需 $O(T)$ 个逐步对数密度，$T\sim10^2$–10^3。沿随机链或桥采样器反传，占用大量内存和计算且可能不稳定；再对每对多次采样、遍历所有三元组，常超实际预算。

走向路径损失的可计算替代。 利用扩散性质与 Jensen 不等式，先得到该损失的上界，再将完整路径似然转化为单步转移的期望；此时仍须对难解的模型桥后验采样，尚未得到可计算的实践目标。因为 $-\log\sigma(\cdot)$ 凸，将内层期望移至非线性函数外给出

$$\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}})\le-\mathbb{E}_{(c,\mathbf{x}_0^w,\mathbf{x}_0^l)\sim\mathcal{D}}\mathbb{E}_{\substack{\mathbf{x}_{1:T}^w\sim\pi_\theta(\cdot|\mathbf{x}_0^w,c)\\ \mathbf{x}_{1:T}^l\sim\pi_\theta(\cdot|\mathbf{x}_0^l,c)}}\left[\log\sigma\left(R_{\pi_\theta}(c,\mathbf{x}_{0:T}^w)-R_{\pi_\theta}(c,\mathbf{x}_{0:T}^l)\right)\right].$$

用 $R_{\pi_\theta}=\beta\log(\pi_\theta/\pi_{\text{ref}})+\beta\log Z(c)$，赢家输家的常数消去，上界成为

$$\mathcal{L}_{\text{Diff-DPO}}(\theta;\pi_{\text{ref}})\le-\mathbb{E}\left[\log\sigma\left(\beta\left[\log\frac{\pi_\theta(\mathbf{x}_{0:T}^w\mid c)}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^w\mid c)}-\log\frac{\pi_\theta(\mathbf{x}_{0:T}^l\mid c)}{\pi_{\text{ref}}(\mathbf{x}_{0:T}^l\mid c)}\right]\right)\right]. \tag{8.5.9}$$

可计算替代：逐步形式。 再利用逆过程 Markov 性质，把路径偏好分解为逐步贡献的和，最终得到 DPO 式对数 sigmoid 损失，其内部间隔简化为 DSM 式 MSE 之差。具体地，

$$\begin{aligned}\pi_\theta(\mathbf{x}_{0:T}\mid c)&=\pi_\theta(\mathbf{x}_T\mid c)\prod_{t=1}^T\pi_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t,c),\\ \pi_{\text{ref}}(\mathbf{x}_{0:T}\mid c)&=\pi_{\text{ref}}(\mathbf{x}_T\mid c)\prod_{t=1}^T\pi_{\text{ref}}(\mathbf{x}_{t-1}\mid\mathbf{x}_t,c),\\ \frac{\pi_\theta(\mathbf{x}_{0:T}\mid c)}{\pi_{\text{ref}}(\mathbf{x}_{0:T}\mid c)}&=\frac{\pi_\theta(\mathbf{x}_T\mid c)}{\pi_{\text{ref}}(\mathbf{x}_T\mid c)}\prod_{t=1}^T\frac{\pi_\theta(\mathbf{x}_{t-1}\mid\mathbf{x}_t,c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1}\mid\mathbf{x}_t,c)}.\end{aligned}$$

若两模型 T 时刻先验相同，首因子为 1，取对数后有

$$\log \frac{\pi_\theta(\mathbf{x}_{0:T} \mid c)}{\pi_{\text{ref}}(\mathbf{x}_{0:T} \mid c)} = \sum_{t=1}^{T} \log \frac{\pi_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}.$$

因此式 (8.5.9) 可写为

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \le -\mathbb{E}\left[\log \sigma\left(\beta \sum_{t=1}^{T} \Delta_t\right)\right],$$
$$\Delta_t = \log \frac{\pi_\theta(\mathbf{x}_{t-1}^w \mid \mathbf{x}_t^w, c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^w \mid \mathbf{x}_t^w, c)} - \log \frac{\pi_\theta(\mathbf{x}_{t-1}^l \mid \mathbf{x}_t^l, c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1}^l \mid \mathbf{x}_t^l, c)}.$$

为将求和化为单个随机转移，注意 $\beta \sum_{s=1}^{T} \Delta_s = \mathbb{E}_{t \sim \mathcal{U}\{1,\dots,T\}}[\beta T \Delta_t]$。再由凸性与 Jensen 不等式，并取既有外层期望，得到

$$\mathcal{L}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) \le -\mathbb{E}\left[\log \sigma(\beta T \Delta_t)\right],$$

期望覆盖数据对、均匀时间 t，以及 $\mathbf{x}_{t-1:t}^{w/l} \sim \pi_\theta(\cdot \mid \mathbf{x}_0^{w/l}, c)$。虽然上界只依赖一次转移，抽取端点条件转移对仍困难。

遵循 Diffusion-DPO，以固定正向加噪过程近似难解的模型条件路径。对每个干净端点，先采样 $\mathbf{x}_t \sim p_t(\mathbf{x}_t \mid \mathbf{x}_0)$，给定 $(\mathbf{x}_0, \mathbf{x}_t)$，正向过程诱导可计算后验 $p(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$。在它上面对逆转移对数比平均，得到

$$\mathbb{E}_{p(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)}\left[\log \frac{\pi_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}\right]$$
$$= -D_{\text{KL}}\big(p(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \| \pi_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)\big)$$
$$+ D_{\text{KL}}\big(p(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \| \pi_{\text{ref}}(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)\big).$$

若逆核为具有相同指定逆向方差的高斯，这些 KL 化为加权去噪回归误差。在 $\boldsymbol{\epsilon}$ 预测下，

$$\mathbb{E}_{p(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)}\left[\log \frac{\pi_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}{\pi_{\text{ref}}(\mathbf{x}_{t-1} \mid \mathbf{x}_t, c)}\right]$$
$$= -\lambda_t \left[\|\widehat{\boldsymbol{\epsilon}}_\theta(\mathbf{x}_t, t, c) - \boldsymbol{\epsilon}\|^2 - \|\widehat{\boldsymbol{\epsilon}}_{\text{ref}}(\mathbf{x}_t, t, c) - \boldsymbol{\epsilon}\|^2\right], \tag{8.5.10}$$

其中 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，$\lambda_t > 0$ 汇集噪声调度权重。

为简记，对任意加噪样本 $(\mathbf{x}_t, \boldsymbol{\epsilon})$ 定义

$$\Delta\text{MSE}(\mathbf{x}_t; \boldsymbol{\epsilon}) := \|\widehat{\boldsymbol{\epsilon}}_\theta(\mathbf{x}_t, t, c) - \boldsymbol{\epsilon}\|^2 - \|\widehat{\boldsymbol{\epsilon}}_{\text{ref}}(\mathbf{x}_t, t, c) - \boldsymbol{\epsilon}\|^2.$$

由此给出 $\mathcal{L}_{\text{Diff-DPO}}$ 的实践单步替代：

$$\widetilde{\mathcal{L}}_{\text{Diff-DPO}}(\theta; \pi_{\text{ref}}) := -\mathbb{E}_{\substack{(c, \mathbf{x}_0^w, \mathbf{x}_0^l) \sim \mathcal{D} \\ t \sim \mathcal{U}\{1,\dots,T\},\ \boldsymbol{\epsilon}^w, \boldsymbol{\epsilon}^l \sim \mathcal{N}(\mathbf{0}, \mathbf{I})}} \Big[\log \sigma\Big(\beta T \lambda_t \big[\Delta\text{MSE}(\mathbf{x}_t^l; \boldsymbol{\epsilon}^l) - \Delta\text{MSE}(\mathbf{x}_t^w; \boldsymbol{\epsilon}^w)\big]\Big)\Big],$$

其中 $\mathbf{x}_t^w = \alpha_t \mathbf{x}_0^w + \sigma_t \boldsymbol{\epsilon}^w$，$\mathbf{x}_t^l = \alpha_t \mathbf{x}_0^l + \sigma_t \boldsymbol{\epsilon}^l$。实践中也可用共享噪声 $\boldsymbol{\epsilon}^w = \boldsymbol{\epsilon}^l$ 降低方差；它不改变整体 DPO 形式，但略微改变随机估计器。

直观上，最小化此替代损失会增大相对参考归一化后的赢家–输家间隔。等价地，鼓励模型相对冻结参考，在赢家上比输家上更大幅降低去噪误差。参考模型不贡献直接梯度，却仍位于 $\log \sigma(\cdot)$ 非线性内部的间隔中，影响 DPO 式逐样本权重。[11]

[11] 译注：前两次 Jensen 给出针对原端点条件路径分布的上界；随后以固定正向路径替代模型桥后验，是额外近似。

8.6 结束语

本章将视线从基础原理转向可控生成的实践挑战。条件得分的 Bayes 分解建立统一引导框架，将生成过程分为无条件方向与引导项。

这一原则体现在多种方法中。需专门训练的方法包括使用外部分类器的 CG，以及在单个模型内学习条件与无条件得分、更高效的 CFG。灵活的免训练引导则从任务损失定义替代势，在推断时引导预训练模型，涵盖艺术控制到逆问题求解等应用，无需重训扩散模型。

在条件化之外，我们讨论输出与人类偏好对齐。回顾标准但复杂的 RLHF 后，介绍更直接、稳定的 DPO 及其扩散推广 Diffusion-DPO：从偏好数据直接导出损失，绕开显式奖励模型与强化学习。

这些方法组成引导生成的工具箱，但迭代采样本身的计算成本与时延仍是重大障碍。解决生成什么之后，下一章转向生成有多快：

1. 利用采样等价于求解 ODE，探索大幅减少所需步骤的高阶数值求解器；
2. 研究 DDIM、DEIS 和 DPM-Solver 系列等有影响的方法，了解其如何通过数量级的加速提高扩散模型实用性。

此外，在给定端点、当前含噪状态和时间后，先对随机单步转移的对数比间隔求条件平均，再将其放入非线性损失，也是独立的一步。对 $f(z) = -\log\sigma(z)$，凸性给出 $f(\mathbb{E}[Z \mid X]) \le \mathbb{E}[f(Z) \mid X]$；因此在同一固定正向桥条件律下，这一步使目标不增。路径分布替换本身则不给出普遍的不等式方向。源文最终称为 surrogate；最终实践目标并不自动成为原损失的严格上界或下界。

第九章　用于快速扩散采样的数值求解器

扩散模型将噪声映射为数据样本，其生成过程可表示为逆时间 SDE 或相应 PF-ODE。它依靠许多小积分步近似解轨迹（微分方程简介见附录 A），本来就较慢。因此，加速推断成为核心研究目标。现有方法大致分为：

- **免训练方法：**本章重点，不增加训练，通过先进数值求解器提高采样效率；
- **基于训练的方法：**第 10、11 章介绍，将预训练模型蒸馏为快速生成器，或直接学习 ODE 流映射（解），使采样仅需少数几步。

SDE 采样器（如 Euler–Maruyama）因随机性可能产生更多样的样本，但通常需要更多步骤（Xu et al., 2023）。此处专注 ODE 生成，其原则自然延伸到 SDE。

学完本章后，你将能够：

- 将扩散采样看作 PF-ODE 的数值积分问题；
- 区分模型近似误差与数值离散误差；
- 理解 DDIM、DEIS、DPM-Solver 和 DPM-Solver++ 的主要数值思想；
- 联系现代扩散采样器与 Euler、Runge–Kutta（RK）、Adams–Bashforth（AB）和指数积分器等经典方法。

阅读路线。　不熟悉微分方程或数值求解器的读者可先阅读附录 A。阅读本章时始终注意：每个求解器精确积分什么，又对什么作数值近似？

9.1　序幕

9.1.1　快速采样作为数值积分

得分 SDE 框架（Song et al., 2020c）把离散扩散及基于 ELBO 的表述（Sohl-Dickstein et al., 2015; Ho et al., 2020），联系到连续 SDE/ODE 生成建模。它使采样具有清楚图景：模型训练后，生成可视作求解学习到的微分方程，从噪声返回数据。

实际困难是速度。朴素采样器以许多小步跟踪逆时间轨迹，常需数百乃至数千次网络求值。快速采样问，能否用远少于此的模型调用近似同一生成过程。本章固定预训练模型，设计更好的采样数值求解器；蒸馏或直接少步训练等方法留待第 10、11 章。

要点：扩散模型训练后，免训练快速采样在很大程度上就是数值积分问题。

众多采样器名称容易使主题显得零散。本章先介绍背后少量数值思想，再联系熟悉的方法名，说明它们不是互不相关的技巧，而是近似同一 PF-ODE 轨迹的不同方式。

采样即求解经验 PF-ODE。 给定预训练得分模型 $\mathbf{s}_{\phi^\times}(\mathbf{x},t)\approx\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$（或第 6.3.1 节其他参数化），用学习模型替换真实得分，得到

$$\frac{d\mathbf{x}(t)}{dt}=\mathbf{f}(\mathbf{x}(t),t)-\frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x}(t),t).$$

从 $\mathbf{x}(T)\sim p_{\text{prior}}$ 出发，生成将此 ODE 从 T 逆向积分到 0。对 $s>t$，精确经验更新为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)=\mathbf{x}_s+\int_s^t\left[\mathbf{f}(\mathbf{x}(\tau),\tau)-\frac{1}{2}g^2(\tau)\mathbf{s}_{\phi^\times}(\mathbf{x}(\tau),\tau)\right]d\tau. \tag{9.1.1}$$

$\widetilde{\Psi}$ 是以学习模型替换理想得分后的经验 PF-ODE 流映射；流映射仍是原式 (4.2.2) 引入的经典 ODE 解映射。相应理想流记作 $\Psi_{s\to t}$，期望 $\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)\approx\Psi_{s\to t}(\mathbf{x}_s)$。

积分一般无闭式，因此数值采样器使用递减网格

$$T=t_0>t_1>\cdots>t_M=0, \tag{9.1.2}$$

从 $\widetilde{\mathbf{x}}_{t_0}=\mathbf{x}_T\sim p_{\text{prior}}$ 出发，生成序列 $\widetilde{\mathbf{x}}_{t_0},\dots,\widetilde{\mathbf{x}}_{t_M}$，其中 $\widetilde{\mathbf{x}}_{t_i}$ 近似 $\widetilde{\Psi}_{T\to t_i}(\mathbf{x}_T)$，以最后迭代为样本。因此本章各免训练求解器都回答：

问题 9.1.1. *如何以尽可能少的模型求值，准确近似 PF-ODE 积分？*

求解器设计中三个独立选择。

1. **预测参数化：**预训练模型提供得分、噪声、干净数据还是速度？
2. **时间参数化：**以哪个变量度量同一连续轨迹上的进度？原扩散时间 t 是一种，后面还会引入其他重参数化。
3. **数值近似：**如何在有限区间近似未知模型相关量？只用当前求值、增加步内求值，或复用之前各步求值？

前两者决定提交给求解器的数值形式，第三者决定如何利用模型求值。

如何使用模型求值？ 可按下一次更新的信息来源组织求解器：从当前状态出发，在本步获得更多信息，或复用已完成步骤的信息。

单步方法只使用当前状态和同一时间区间内的求值构造下一状态。Euler 仅用当前速度；高阶 RK 在结束一步前还可在一个或多个中间状态计算速度。因此“单步”不等于“一次函数求值”，而是不需要更早已完成步骤的信息。

多步方法复用之前步骤的信息。储存的模型求值描述动力学最近如何变化，无需本步多次新求值也可高阶更新，AB 族是典型例子。

另一种独立思想是改变跨时间的调度：不严格按序计算全部时刻，而在多个时刻初始化状态，反复修正，直至与 ODE 一致。此类不动点迭代允许不同时刻的模型求值并行。Euler、RK、AB 和 Picard 等经典例子见原附录 A.1.5，结构组织总结于原式 (A.1.6)。

计算成本与实际表现。 数值时间步未必只需一次网络求值。Euler 每步一次，高阶 RK 可能多次；多步法复用储存结果，初始化后常每步仅需一次新求值。因此用函数求值次数（NFE）度量采样成本。若每步约 m 次、共 M 步，则 NFE $\approx mM$。例如 CFG（第 8.3 节）同时需要条件和无条件预测，粗略使每步网络成本翻倍。

经典分类告诉我们数值信息的来源与成本。扩散 PF-ODE 还提供额外机会：向量场不是全部未知。视预测参数化而定，一部分由已知噪声调度解析确定，只有剩余量需要网络求值。下面考察暴露这一分离如何改变 PF-ODE 数值形式、启发扩散专用积分器。

9.1.2 扩散专用求解器的设计

原附录 A.1.4 的经典方法通过向量场求值处理一般 ODE。扩散另有结构：噪声调度解析已知，模型预测由神经网络给出。因此不必以相同方式近似所有动力学，可解析保留已知调度项，只近似模型预测。参数化决定该结构呈现得多清楚。

I：得分之外的参数化。 现代实现常用噪声、干净数据或速度预测。它们代数相关，却暴露不同数值结构。避免直接预测得分还有稳定性原因：$t \to 0$ 时，真实得分可能变化极快，尤其数据集中于低维流形附近（Kim et al., 2022），网络直接近似得分在小噪声附近难保持准确。[1]

常用替代是预测噪声 $\boldsymbol{\epsilon}_{\phi^\times}$，或干净数据、速度。噪声形式中 $\mathbf{s}_{\phi^\times}(\mathbf{x},t) = -\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x},t)/\sigma_t$。但网络提供的量只是设计的一部分，下面考察同一 PF-ODE 在不同参数化下的数值呈现。

II：一个 PF-ODE，两种数值形式。 **直接速度形式**最直观：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_{\phi^\times}(\mathbf{x}(t),t). \tag{9.1.3}$$

此处 $\mathbf{v}$ 预测直接提供完整经验 PF-ODE 速度，积分器把整个右端作为整体离散。

因子化半线性形式由得分、噪声和干净数据预测自然暴露：

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{a(t)\mathbf{x}(t)}_{\text{已知线性部分}} + \underbrace{b(t)}_{\text{已知系数}}\ \underbrace{\mathbf{N}_{\phi^\times}(\mathbf{x}(t),t)}_{\text{神经求值}}, \quad \mathbf{N}_{\phi^\times} \in \{\mathbf{s}_{\phi^\times}, \boldsymbol{\epsilon}_{\phi^\times}, \mathbf{x}_{\phi^\times}\}. \tag{9.1.4}$$

a, b 由调度确定，$\mathbf{N}$ 为网络预测。[2]半线性指首项对状态线性，神经项可以非线性依赖状态。分解并不唯一，但可解析处理已知线性部分，仅数值近似神经贡献。

三种参数化的系数见表 9.1。[3]例如噪声预测时，

$$\frac{d\mathbf{x}(t)}{dt} = \underbrace{f(t)\mathbf{x}(t)}_{\text{线性部分}} + \underbrace{\frac{1}{2}\frac{g^2(t)}{\sigma_t}\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}(t),t)}_{\text{非线性神经部分}}. \tag{9.1.5}$$

神经预测的系数完全由调度决定，第二项只有噪声预测需要学习。理想层面四类预测完全等价，

[1]由式 (6.3.1)，$\boldsymbol{\epsilon}^*(\mathbf{x}_t,t) = -\sigma_t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)$，其中理想噪声预测为条件均值、核为 $\mathcal{N}(\mathbf{x}_t; \alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I})$。$L^2$ 条件期望正交性给出 $\mathbb{E}\|\boldsymbol{\epsilon}\|_2^2 = \mathbb{E}\|\boldsymbol{\epsilon}^*\|_2^2 + \mathbb{E}\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}^*\|_2^2$，所以 $\mathbb{E}\|\boldsymbol{\epsilon}^*\|_2^2 \le D$，理想噪声预测期望平方范数一致有界。而 $\mathbf{s}^* := \nabla_{\mathbf{x}} \log p_t$ 满足 $\mathbb{E}\|\mathbf{s}^*\|_2^2 = \sigma_t^{-2}\mathbb{E}\|\boldsymbol{\epsilon}^*\|_2^2 \le D/\sigma_t^2$。因噪声预测转得分带有 $1/\sigma_t$，σ_t 变小时直接得分预测的尺度可能恶化，小噪声时数值上较不利。

[2]标准半线性记号可将 $b(t)\mathbf{N}_{\phi^\times}$ 吸收到一个非线性项；这里分开，因为 $b(t)$ 解析已知，而网络预测需要求值。求解器因而可只近似积分内预测、保留并解析积分已知系数。

[3]下文交替使用 SDE 系数 $f(t), g(t)$ 与高斯核系数 α_t, σ_t，关系为 $f(t) = \alpha_t'/\alpha_t$，$g^2(t) = \frac{d}{dt}(\sigma_t^2) - 2(\alpha_t'/\alpha_t)\sigma_t^2 = 2\sigma_t\sigma_t' - 2(\alpha_t'/\alpha_t)\sigma_t^2$。

表 9.1: 得分、噪声与干净数据预测的因子化 PF-ODE。

预测	$a(t)$	$b(t)$	$\mathbf{N}_{\phi\times}$
得分	$f(t)$	$-\frac{1}{2}g^2(t)$	$\mathbf{s}_{\phi\times}$
噪声	$f(t)$	$\frac{1}{2}g^2(t)/\sigma_t$	$\boldsymbol{\epsilon}_{\phi\times}$
干净数据	σ_t'/σ_t	$\alpha_t(\alpha_t'/\alpha_t - \sigma_t'/\sigma_t)$	$\mathbf{x}_{\phi\times}$

表示同一 PF-ODE。经验模型中，若从同一模型输出精确代数转换（式 (6.3.1)），等价性仍成立；各式暴露的数值结构不同，但描述同一学习连续动力学。若不同目标由分别训练的网络实现，则经验 ODE 不必完全重合，采样器差异可能同时反映模型近似与数值离散。

III：半线性 PF-ODE 的指数积分器。 对 $s > t$，定义积分因子

$$E(s \to t) := \exp\left(\int_s^t a(u)\,du\right).$$

常数变易公式给出精确经验流

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = E(s\to t)\mathbf{x}_s + \int_s^t E(\tau\to t)b(\tau)\mathbf{N}_{\phi\times}(\mathbf{x}_\tau,\tau)\,d\tau. \tag{9.1.6}$$

一般推导见原附录 A.1.3。噪声预测时 $a = f$、$b = g^2/(2\sigma_t)$、$\mathbf{N} = \boldsymbol{\epsilon}$，所以

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \underbrace{E(s\to t)\mathbf{x}_s}_{\text{精确线性演化}} + \frac{1}{2}\int_s^t \frac{g^2(\tau)}{\sigma_\tau}E(\tau\to t)\boldsymbol{\epsilon}_{\phi\times}(\mathbf{x}_\tau,\tau)\,d\tau, \tag{9.1.7}$$

其中 $E(s\to t) = \exp(\int_s^t f(u)du)$。积分因子与系数 b 已知，唯一未知是沿轨迹计算的网络预测。显式保留已知因子，使一阶近似只作用于神经预测，而不是将 $b\mathbf{N}$ 吸收成一个未知残差。

因子化指数积分形式为何有用？ 从时刻 s 的精确经验状态 $\mathbf{x}_s$ 向 $t < s$ 走一步，记 $\Delta s := s - t > 0$、$\mathbf{N}_s := \mathbf{N}_{\phi\times}(\mathbf{x}_s, s)$。普通 Euler 将完整速度冻结，得到

$$\widetilde{\mathbf{x}}_t^{\text{Euler}} = \mathbf{x}_s - \Delta s[a(s)\mathbf{x}_s + b(s)\mathbf{N}_s]. \tag{9.1.8}$$

若只冻结神经预测，而保留已知调度，得到一阶因子化指数积分更新[4]

$$\widetilde{\mathbf{x}}_t^{\text{EI}} = E(s\to t)\mathbf{x}_s + \left[\int_s^t E(\tau\to t)b(\tau)\,d\tau\right]\mathbf{N}_s. \tag{9.1.9}$$

两者每步均只用一次网络求值。普通 Euler 冻结完整速度；因子化更新保留调度，只冻结预测。若把 $b(\tau)\mathbf{N}$ 整体当残差冻结，则是常规指数 Euler。因子化形式额外在积分内保留已知 $b(\tau)$；b 在本步为常数时，两指数更新重合。

[4]它不是原状态和时间变量下的普通 Euler；对状态作积分因子变换，并在相应时间坐标单调的区间作时间重参数化，可将它写为普通显式 Euler。DDIM 一节将具体说明。

例如 $a(t)\equiv a$、$b(t)\equiv b$、$\mathbf{N}_{\phi^\times}(\mathbf{x}_\tau,\tau)\equiv\mathbf{N}_s$ 时，对 $a\neq 0$，

$$\begin{aligned}\widetilde{\mathbf{x}}_t^{\mathrm{EI}}&=e^{-a\Delta s}\mathbf{x}_s+\frac{b}{a}(e^{-a\Delta s}-1)\mathbf{N}_s,\\ \widetilde{\mathbf{x}}_t^{\mathrm{Euler}}&=(1-a\Delta s)\mathbf{x}_s-b\Delta s\mathbf{N}_s,\\ \widetilde{\mathbf{x}}_t^{\mathrm{EI}}&=\widetilde{\mathbf{x}}_t^{\mathrm{Euler}}+\frac{(\Delta s)^2}{2}[a^2\mathbf{x}_s+ab\mathbf{N}_s]+O((\Delta s)^3).\end{aligned}$$

小步下一阶相同，因子化形式还保留已知动力学的高阶效应，大步时可能很重要。如 $a>0$，精确乘子 $e^{-a\Delta s}$ 对所有 $\Delta s>0$ 都为正且收缩；Euler 的 $1-a\Delta s$ 在 $a\Delta s>1$ 后为负、在 $a\Delta s>2$ 后模大于 1，可能扭曲已被因子化形式解析处理的动力学。

完整 PF-ODE 的神经预测一般沿轨迹变化。精确式减去式 (9.1.9) 得

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{EI}}=\int_s^t E(\tau\to t)b(\tau)[\mathbf{N}_{\phi^\times}(\mathbf{x}_\tau,\tau)-\mathbf{N}_s]d\tau. \tag{9.1.10}$$

解析处理已知调度后，剩余离散误差由神经预测沿轨迹的变化控制。这是多个扩散专用求解器以不同方式利用的基本原则。

9.1.3 从数值思想到扩散采样器的路线图

第 9.2 节从当前预测构造 DDIM 一阶更新；第 9.3 节用前面步骤预测构造 DEIS 高阶近似；第 9.4 节通过本步额外求值构造 DPM-Solver 高阶更新；第 9.5 节从干净数据预测出发，构造步内额外求值的 DPM-Solver++(2S)，及复用此前求值的多步 DPM-Solver++(2M)；最后原第 9.6 节的 ParaDiGMS 以不动点迭代一起更新多个时刻，实现时间并行。这些联系提供高层路线

连接经典数值思想与扩散采样器的路线图（原文无编号）。

经典思想	更新构造	扩散例子	源节号
Euler 式一阶更新	用步首模型预测推进	DDIM；DPM-Solver-1	9.2、9.4
RK 式分阶段更新	在步内额外中间状态求值	高阶 DPM-Solver；DPM-Solver++(2S)	9.4、9.5
AB 式多步更新	复用此前步骤的模型预测	DEIS；DPM-Solver++(2M)	9.3、9.5
Picard 式不动点迭代	同时更新多个时刻，反复细化状态	ParaDiGMS	9.6

图。扩散求解器还利用 PF-ODE 特有的预测参数化、已知调度系数及替代时间参数化。为系统呈现，各节均先推导求解器并解释数值思想，再联系经典求解器原则，最后联系本章其他扩散求解器，明确共同数值骨架与各方法特有成分。

9.2 DDIM

去噪扩散隐式模型（DDIM；Song et al., 2020a）是最早且最常用的加速方法之一。它最初从概率视角提出，但确定性更新也有清楚的 PF-ODE 解释。因此这里先将它纳入数值 ODE 求解的统一框架，原变分视角留待第 9.2.3 节。

序幕留下具体问题：解析保留已知调度因子后，如何近似剩余积分内的网络预测？DDIM 采用最简单答案：使用步首值。先推导更新，再说明与经典 Euler、高阶扩散求解器的关系。

9.2.1 DDIM 作为一阶扩散求解器

考虑从时刻 s 的起点 $\widetilde{\mathbf{x}}_s$ 向 $t < s$ 采样一步。[5]噪声参数化下，式 (9.1.7) 给出精确经验流

$$\widetilde{\Psi}_{s\to t}(\widetilde{\mathbf{x}}_s) = E(s\to t)\widetilde{\mathbf{x}}_s + \frac{1}{2}\int_s^t \frac{g^2(\tau)}{\sigma_\tau} E(\tau\to t)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau)d\tau.$$

已知调度因子保持解析，未知量只有沿未知轨迹的预测。确定性 DDIM 将噪声预测冻结为步首值：$\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau) \approx \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)$，$\tau \in [t,s]$，得到

$$\widetilde{\mathbf{x}}_t = E(s\to t)\widetilde{\mathbf{x}}_s + \left[\frac{1}{2}\int_s^t \frac{g^2(\tau)}{\sigma_\tau} E(\tau\to t)d\tau\right]\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s).$$

由 $f(t) = \alpha_t'/\alpha_t$，积分因子为 $E(s\to t) = \alpha_t/\alpha_s$，且

$$\frac{1}{2}\frac{g^2(\tau)}{\sigma_\tau}E(\tau\to t) = \alpha_t \frac{d}{d\tau}\left(\frac{\sigma_\tau}{\alpha_\tau}\right).$$

预测冻结后，积分可由调度精确求出。

命题 9.2.1 (DDIM 作为一阶因子化 EI 更新)**.** *对 $s > t$，确定性 DDIM 为*

$$\widetilde{\mathbf{x}}_t = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s + \alpha_t\left(\frac{\sigma_t}{\alpha_t} - \frac{\sigma_s}{\alpha_s}\right)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s). \tag{9.2.1}$$

证明. 从 s 到 t 积分 $\frac{d}{d\tau}(\sigma_\tau/\alpha_\tau)$ 即得。 □

所以 DDIM 保留整个区间的已知调度演化，仅忽略预测变化。

干净数据预测下也可类似推导。精确经验流为

$$\widetilde{\Psi}_{s\to t}(\widetilde{\mathbf{x}}_s) = \frac{\sigma_t}{\sigma_s}\widetilde{\mathbf{x}}_s + \sigma_t\int_s^t \frac{d}{d\tau}\left(\frac{\alpha_\tau}{\sigma_\tau}\right)\mathbf{x}_{\phi^\times}(\mathbf{x}_\tau,\tau)d\tau.$$

冻结步首干净预测并精确积分已知系数，得

$$\widetilde{\mathbf{x}}_t = \frac{\sigma_t}{\sigma_s}\widetilde{\mathbf{x}}_s + \alpha_s\left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s}\right)\mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s).$$

分别在噪声形式冻结噪声、在数据形式冻结干净预测，得到相同 DDIM 更新。后面的 DPM-Solver 与 DPM-Solver++ 分别从这两种形式构造高阶近似，此对应会再次出现。

等价形式及解释。 理想层面的预测目标由式 (6.3.1) 逐点代数等价，因此可在起点用干净数据或得分预测重写，而不改变有限步更新。

[5]本章 $\widetilde{\mathbf{x}}_s$ 表示初始化当前求解器步骤的状态，通常来自前次数值步；波浪号将它与精确扩散分布中的理想样本 $\mathbf{x}_s \sim p_s$，或条件样本 $\mathbf{x}_s \sim p_s(\cdot \mid \mathbf{x}_0)$ 区分。因此 $\widetilde{\mathbf{x}}_s$ 不必精确服从 p_s。

推论 9.2.1 (确定性 DDIM 更新的等价形式)**.** 设 $s>t$，时刻 s 的状态为 $\widetilde{\mathbf{x}}_s$。理想确定性 *DDIM* 具有等价表达

$$\begin{aligned}\widetilde{\mathbf{x}}_t &= \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s + \alpha_t\left(\frac{\sigma_t}{\alpha_t}-\frac{\sigma_s}{\alpha_s}\right)\boldsymbol{\epsilon}^*(\widetilde{\mathbf{x}}_s,s)\\ &= \frac{\sigma_t}{\sigma_s}\widetilde{\mathbf{x}}_s + \alpha_s\left(\frac{\alpha_t}{\alpha_s}-\frac{\sigma_t}{\sigma_s}\right)\mathbf{x}^*(\widetilde{\mathbf{x}}_s,s)\\ &= \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s + \sigma_s^2\left(\frac{\alpha_t}{\alpha_s}-\frac{\sigma_t}{\sigma_s}\right)\mathbf{s}^*(\widetilde{\mathbf{x}}_s,s)\\ &= \alpha_t\underbrace{\mathbf{x}^*(\widetilde{\mathbf{x}}_s,s)}_{\substack{\approx\mathbf{x}_{\phi\times}\\ \text{估计干净样本}}} + \sigma_t\underbrace{\boldsymbol{\epsilon}^*(\widetilde{\mathbf{x}}_s,s)}_{\substack{\approx\boldsymbol{\epsilon}_{\phi\times}\\ \text{估计噪声}}}.\end{aligned} \tag{9.2.2}$$

最后一式给出直观解释：保持从 $\widetilde{\mathbf{x}}_s$ 推断的干净与噪声估计不变，按目标调度重新组合。它模拟高斯正向路径的共享噪声耦合 $\mathbf{x}_\tau=\alpha_\tau\mathbf{x}_0+\sigma_\tau\boldsymbol{\epsilon}$：给定固定对 $(\mathbf{x}_0,\boldsymbol{\epsilon})$，改变时间只改变系数。DDIM 对步首可用估计应用同一思想。

译注： 本节涉及 $\alpha_s,\alpha_t,\sigma_s$ 及中间时刻 σ_τ 等分母的比值，只在相应分母非零、调度定义良好的区间使用。若取零噪端点，须在存在时取适当极限，不能直接对零除。下述 $c_{t,s}=0$ 的高斯核应理解为集中于其均值的 Dirac 概率测度，而非具有普通 Lebesgue 密度的非退化高斯；目标方差为零的端点也按退化测度或相应极限理解。

条件层面若干净样本和噪声固定，重组精确跟踪共享噪声路径；边缘层面的 $\mathbf{x}^*,\boldsymbol{\epsilon}^*$ 则是从当前状态推断的后验估计。因此有限 DDIM 步一般是边缘 PF-ODE 流的近似，而非精确从 p_t 抽样。

冻结哪种预测为何重要？ 固定状态和时间下预测代数等价；有限步还额外冻结区间上一种预测。只有转换后预测也沿近似轨迹保持不变，冻结近似才在参数转换下保留。

设 $\widehat{\mathbf{x}}_0:=\mathbf{x}_{\phi\times}(\widetilde{\mathbf{x}}_s,s)$、$\widehat{\boldsymbol{\epsilon}}:=\boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_s,s)$；若模型只预测其中一个，另一个由式 (6.3.1) 定义，故 $\widetilde{\mathbf{x}}_s=\alpha_s\widehat{\mathbf{x}}_0+\sigma_s\widehat{\boldsymbol{\epsilon}}$。冻结此对，得到整步 DDIM 插值

$$\widetilde{\mathbf{x}}_\tau^{\mathrm{DDIM}}=\alpha_\tau\widehat{\mathbf{x}}_0+\sigma_\tau\widehat{\boldsymbol{\epsilon}},\qquad \tau\in[t,s].$$

不需额外模型求值：系数全已知，$\tau=s$ 恢复起点，$\tau=t$ 给出更新，中间值描述 DDIM 近似诱导的有限步轨迹。沿此轨迹，

$$\frac{\widetilde{\mathbf{x}}_\tau^{\mathrm{DDIM}}-\sigma_\tau\widehat{\boldsymbol{\epsilon}}}{\alpha_\tau}=\widehat{\mathbf{x}}_0,\qquad \frac{\widetilde{\mathbf{x}}_\tau^{\mathrm{DDIM}}-\alpha_\tau\widehat{\mathbf{x}}_0}{\sigma_\tau}=\widehat{\boldsymbol{\epsilon}}.$$

所以代数转换后的干净和噪声预测同时保持常数，两种冻结方式得到同一更新；固定对构成共享噪声路径的两成分，系数给出已知时变权重。

但相应得分与速度一般随时间变化。例如将冻结噪声转换到中间时刻得分，

$$\mathbf{s}(\widetilde{\mathbf{x}}_\tau^{\mathrm{DDIM}},\tau)=-\frac{\widehat{\boldsymbol{\epsilon}}}{\sigma_\tau}=\frac{\sigma_s}{\sigma_\tau}\mathbf{s}_{\phi\times}(\widetilde{\mathbf{x}}_s,s).$$

因此直接冻结原得分会给出不同有限步近似，一般是另一种一阶因子化求解器。类似地，固定干净/噪声对诱导速度 $\frac{d}{d\tau}\widetilde{\mathbf{x}}_\tau^{\mathrm{DDIM}}=\alpha'_\tau\widehat{\mathbf{x}}_0+\sigma'_\tau\widehat{\boldsymbol{\epsilon}}$，调度导数变化时速度也变化。直接冻结完整速度则为原时间下普通 Euler。

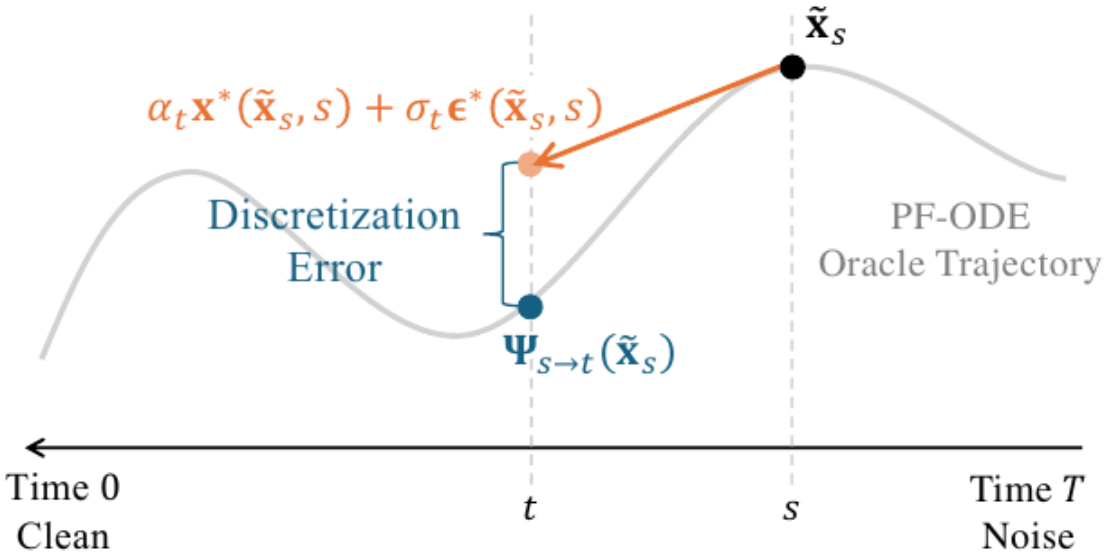


图 9.1: 有限步 DDIM 与经验 PF-ODE 流。由 $\tilde{\mathbf{x}}_s$ 出发，经验流连续到达 $\widetilde{\Psi}_{s\to t}(\tilde{\mathbf{x}}_s)$，DDIM 则整步保留步首预测、解析演化已知调度。差异是式 (9.2.3) 的单步离散误差。原图内 PF-ODE Oracle Trajectory、Ψ 标为理想轨迹，与图注的 empirical/$\widetilde{\Psi}$ 不一致，照录原图并记录疑点；时间由右端噪声至左端干净样本。来源：原作者。

> **注**。预测参数化逐点代数等价，但有限步冻结一般不与时变转换交换。DDIM 冻结一致的步首干净/噪声对；相应得分和完整速度通常在步内变化。因此直接冻结原得分或速度定义不同的一阶方法，速度情形下节将量化。

9.2.2 与 Euler 类方法的关系

DDIM 是一阶方法，但与经典 Euler 的关系需谨慎：分离调度和学习预测后，有限步冻结什么，会产生不同一阶方案。比较三种各需一次求值的构造：

1. 普通 Euler，冻结完整 PF-ODE 速度；
2. 指数 Euler，解析保留线性传播，冻结其余系数加权残差；
3. DDIM，冻结步首干净/噪声估计，保留已知调度的有限步演化。

干净/噪声形式最能体现与普通 Euler 的差异；因子化形式则澄清与指数 Euler 的关系。随后量化剩余误差，给出在调度对齐坐标变换下 DDIM 精确成为 Euler 的意义。

DDIM 与普通 Euler。 二者使用相同步首模型信息，但有限步传播方式不同。前者保留已知调度的有限演化，后者局部近似完整速度。光滑调度下，一阶相同，一般相差 $O((\Delta s)^2)$。

令 $\Delta s = s - t > 0$，步首预测代数一致，则

$$\begin{aligned}
\widetilde{\mathbf{x}}_s &= \alpha_s \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + \sigma_s \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s),\\
\mathbf{v}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) &= \alpha'_s \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + \sigma'_s \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s),\\
\widetilde{\mathbf{x}}_t^{\mathrm{Euler}} &= \widetilde{\mathbf{x}}_s - \Delta s \mathbf{v}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s),\\
\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}} &= \widetilde{\mathbf{x}}_s + (\alpha_t - \alpha_s)\mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + (\sigma_t - \sigma_s)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s).
\end{aligned}$$

精确差异为

$$\begin{aligned}
\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}} - \widetilde{\mathbf{x}}_t^{\mathrm{Euler}} = {} & [\alpha_t - \alpha_s + \Delta s \alpha'_s]\mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)\\
& + [\sigma_t - \sigma_s + \Delta s \sigma'_s]\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s).
\end{aligned}$$

光滑时，$\alpha_t - \alpha_s + \Delta s \alpha'_s = (\Delta s)^2 \alpha''_s/2 + O((\Delta s)^3)$，$\sigma$ 类似，故

$$\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}} - \widetilde{\mathbf{x}}_t^{\mathrm{Euler}} = \frac{(\Delta s)^2}{2}[\alpha''_s \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + \sigma''_s \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)] + O((\Delta s)^3).$$

Euler 以局部线性化替代有限调度变化，DDIM 保留其解析演化。若两调度在区间内均仿射，则 $\alpha_t - \alpha_s = -\Delta s \alpha'_s$，$\sigma_t - \sigma_s = -\Delta s \sigma'_s$，两方法精确重合。例如 $(\alpha_t, \sigma_t) = (1, t)$ 或 $(1 - t, t)$（另见原第 6.3.4 节）。有限步差异由原时间中的调度非线性驱动。

DDIM 与指数 Euler。 噪声形式中 $a(\tau) = f(\tau)$、$b(\tau) = g^2(\tau)/(2\sigma_\tau)$。常规指数 Euler 冻结整个 $b(\tau)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau)$，DDIM 只冻结噪声预测：

$$\begin{aligned}
\widetilde{\mathbf{x}}_t^{\mathrm{ExpEuler}} &= E(s \to t)\widetilde{\mathbf{x}}_s + b(s)\left[\int_s^t E(\tau \to t) d\tau\right] \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s),\\
\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}} &= E(s \to t)\widetilde{\mathbf{x}}_s + \left[\int_s^t E(\tau \to t) b(\tau) d\tau\right] \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s),\\
\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}} - \widetilde{\mathbf{x}}_t^{\mathrm{ExpEuler}} &= \left[\int_s^t E(\tau \to t)(b(\tau) - b(s)) d\tau\right] \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)\\
&= \frac{(\Delta s)^2}{2} b'(s) \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s) + O((\Delta s)^3),
\end{aligned}$$

最后一式要求 b 光滑。二者一阶相同；b 为常数时精确重合，包括序幂例子。三种方案仅区别于在常数近似前保留多少已知结构，记 $\widehat{\boldsymbol{\epsilon}} := \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s, s)$：

$$\begin{aligned}
&\text{普通 Euler：} && f(\tau)\mathbf{x}_\tau + b(\tau)\boldsymbol{\epsilon}_\tau \approx f(s)\widetilde{\mathbf{x}}_s + b(s)\widehat{\boldsymbol{\epsilon}},\\
&\text{指数 Euler：} && b(\tau)\boldsymbol{\epsilon}_\tau \approx b(s)\widehat{\boldsymbol{\epsilon}},\\
&\text{DDIM：} && \boldsymbol{\epsilon}_\tau \approx \widehat{\boldsymbol{\epsilon}}.
\end{aligned}$$

均使用步首一次求值。这种层次只描述保留哪些解析项，并非普适单步误差排序；DDIM 的剩余近似可完全隔离到预测变化。

各方法仍有什么误差？ 局部误差分析令一步从精确经验状态 $\mathbf{x}_s$ 出发。精确流为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}_{\phi^\times}(\mathbf{x}_\tau, \tau) d\tau.$$

三种单步缺陷分别为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{Euler}}=\int_s^t[\mathbf{v}_{\phi^\times}(\mathbf{x}_\tau,\tau)-\mathbf{v}_{\phi^\times}(\mathbf{x}_s,s)]d\tau,$$
$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{ExpEuler}}=\int_s^t E(\tau\to t)[b(\tau)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau)-b(s)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_s,s)]d\tau.$$

DDIM 保留线性传播和系数，仅冻结网络：

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}}=\int_s^t E(\tau\to t)b(\tau)[\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau)-\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_s,s)]d\tau. \tag{9.2.3}$$

相应冻结量沿精确经验轨迹变化慢时，单步近似准确。标准光滑性给出

$$\|\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{Euler}}\|\le\frac{(\Delta s)^2}{2}\sup_{\tau\in[t,s]}\left\|\frac{d}{d\tau}\mathbf{v}_{\phi^\times}(\mathbf{x}_\tau,\tau)\right\|,$$
$$\|\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{ExpEuler}}\|\le\frac{(\Delta s)^2}{2}\sup_{\tau\in[t,s]}|E(\tau\to t)|\sup_{\tau\in[t,s]}\left\|\frac{d}{d\tau}[b(\tau)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau)]\right\|,$$
$$\|\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)-\widetilde{\mathbf{x}}_t^{\mathrm{DDIM}}\|\le\frac{(\Delta s)^2}{2}\sup_{\tau\in[t,s]}|E(\tau\to t)b(\tau)|\sup_{\tau\in[t,s]}\left\|\frac{d}{d\tau}\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau,\tau)\right\|.$$

在通常光滑性与稳定性假设下，三者均全局一阶、每步一次求值。若实际被其冻结的量沿精确轨迹恒定，则该步精确：依次为完整速度、系数加权残差、噪声预测。因此没有普适误差排序。DDIM 特别适合预测缓变而调度显著变化的情形；利用更多已知结构可以减少离散误差，却不保证每步都更小。这些是相对经验 PF-ODE 的数值误差，经验与理想模型不匹配是另一来源。

DDIM 的精确 Euler 解释。 原 $(\mathbf{x},t)$ 中 DDIM 通常不同于普通 Euler；同时改变状态与时间坐标，可得到精确解释。噪声预测下定义 $\mathbf{y}_t:=\mathbf{x}_t/\alpha_t$、$\rho_t:=\sigma_t/\alpha_t$。状态归一化去掉已知信号缩放，新时钟以噪声信号比衡量进度。

先看条件层面，固定 $(\mathbf{x}_0,\boldsymbol{\epsilon})$ 的路径 $\mathbf{x}_t=\alpha_t\mathbf{x}_0+\sigma_t\boldsymbol{\epsilon}$ 满足 $\mathbf{y}_t=\mathbf{x}_0+\rho_t\boldsymbol{\epsilon}$，所以 $d\mathbf{y}/d\rho=\boldsymbol{\epsilon}$。此处噪声是固定潜实现，不是网络预测；已知调度在 ρ 中变为仿射。

经验 ODE 有相同坐标结构，但以状态依赖学习预测代替固定噪声。由式 (9.1.5)，

$$\frac{d\mathbf{x}_t}{dt}=\frac{\alpha_t'}{\alpha_t}\mathbf{x}_t+\left(\sigma_t'-\frac{\alpha_t'}{\alpha_t}\sigma_t\right)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t,t),$$

从而

$$\frac{d\mathbf{y}_t}{dt}=\frac{1}{\alpha_t}\left(\frac{d\mathbf{x}_t}{dt}-\frac{\alpha_t'}{\alpha_t}\mathbf{x}_t\right)=\frac{d\rho_t}{dt}\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t,t). \tag{9.2.4}$$

在 $\alpha_t>0$ 且 ρ_t 严格单调的区间，以 ρ 为时间，记反函数 $t=t(\rho)$，$\overline{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{y},\rho):=\boldsymbol{\epsilon}_{\phi^\times}(\alpha_{t(\rho)}\mathbf{y},t(\rho))$，得到

$$\frac{d\mathbf{y}}{d\rho}=\overline{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{y},\rho). \tag{9.2.5}$$

模型时空依赖仍在，只是改用变换变量。显式 Euler 给出 $\widetilde{\mathbf{y}}_t=\widetilde{\mathbf{y}}_s+(\rho_t-\rho_s)\overline{\boldsymbol{\epsilon}}_{\phi^\times}(\widetilde{\mathbf{y}}_s,\rho_s)$。代回 $\mathbf{y}=\mathbf{x}/\alpha$、$\rho=\sigma/\alpha$，恰为式 (9.2.1)。

坐标选择是数值方法的一部分。可逆时空坐标变化给出同一连续 ODE 解的等价表示；有限步离散一般不具此不变性：先变换再 Euler，未必等于先 Euler 再变换。合适坐标可在离散前吸收已知动力学。DDIM 用 $\mathbf{x}/\alpha$ 去掉信号缩放，$\rho = \sigma/\alpha$ 吸收时间尺度，Euler 仅近似变换网络场。因此 DDIM 通常不同于 $(\mathbf{x}, t)$ 的 Euler，却恰为 $(\mathbf{y}, \rho)$ 的显式 Euler。

干净数据预测有对偶构造：以 σ_t 归一化状态、α_t/σ_t 为时间，

$$\frac{d}{dt}\left(\frac{\mathbf{x}_t}{\sigma_t}\right) = \frac{d}{dt}\left(\frac{\alpha_t}{\sigma_t}\right)\mathbf{x}_{\phi\times}(\mathbf{x}_t, t).$$

相应 DDIM 同样是调度对齐坐标下的显式 Euler。

此观点也预示高阶求解器的坐标作用。DPM-Solver 用半对数 SNR $\lambda_t := \log(\alpha_t/\sigma_t)$，与 Euler 时钟关系为 $\rho_t = e^{-\lambda_t}$、$d\rho = -e^{-\lambda}d\lambda$，因此精确变换方程等价于

$$\mathbf{y}_t = \mathbf{y}_s - \int_{\lambda_s}^{\lambda_t} e^{-\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi\times}(\widehat{\mathbf{x}}_\lambda, \lambda)d\lambda,$$

其中帽号的 λ 记号将在第 9.4 节定义。一阶冻结预测并保留已知换元权重，得到相同有限步更新，所以 DPM-Solver-1 恰为 DDIM。高阶时，在哪个坐标中近似时空依赖预测，成为方法的一部分；λ 使加权积分具有方便的高阶展开。

9.2.3 （可选）DDIM 最初的变分视角

PF-ODE 解释确定性 DDIM 为数值求解器；历史上，它从 DDPM 变分视角提出，起点是另一问题：去噪目标是否唯一确定不同时刻含噪状态的耦合?

重温 DDPM 变分视角。 DDPM 的固定 Markov 推断过程具有高斯单时间扰动边缘 $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I})$。变分推导涉及 $t < s$ 时可计算条件分布 $p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0)$；生成逆模型不能直接以未知干净样本为条件，转而依赖模型预测。

关键是噪声预测损失可写为

$$\mathbb{E}_t\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\|\boldsymbol{\epsilon}_\phi(\alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}, t) - \boldsymbol{\epsilon}\|_2^2\right],$$

它只通过单时间边缘依赖推断过程，不依赖给定干净样本的完整跨时间联合耦合。

原始动机。 同一组扰动边缘可对应许多联合过程，去噪训练目标并不唯一决定跨时间耦合。DDIM 保留训练时边缘，改变噪声水平间依赖。对任意 $t < s$，选择满足单步边缘相容性的条件转移:

$$\int \pi(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0)p_s(\mathbf{x}_s \mid \mathbf{x}_0)d\mathbf{x}_s = p_t(\mathbf{x}_t \mid \mathbf{x}_0). \tag{9.2.6}$$

即输入服从 $p_s(\cdot \mid \mathbf{x}_0)$ 时，转移后服从 $p_t(\cdot \mid \mathbf{x}_0)$。原 Markov DDPM 的 Bayes 逆后验是有效选择[6]，但并非唯一。其他相容耦合可直接连接相隔很远的噪声水平，解释为何同一去噪器可在跳过中间时间的粗网格复用。

[6]对 $\mathbf{x}_0 \to \mathbf{x}_t \to \mathbf{x}_s$、$t < s$ 的 Markov 正向过程，由全概率公式 $p_t(\mathbf{x}_t \mid \mathbf{x}_0) = \int p(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0)p_s(\mathbf{x}_s \mid \mathbf{x}_0)d\mathbf{x}_s$。

离散 DDIM 推导。 给定上述高斯扰动核和 $\mathbf{x}_0 \sim p_{\text{data}}$，考虑高斯族

$$\pi(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; a_{t,s}\mathbf{x}_0 + b_{t,s}\mathbf{x}_s, c_{t,s}^2\mathbf{I}), \tag{9.2.7}$$

三系数决定如何组合当前状态、干净样本和新噪声。先抽取 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}'$，再按此核抽取；等价地，

$$\begin{aligned}\mathbf{x}_t &= a_{t,s}\mathbf{x}_0 + b_{t,s}\mathbf{x}_s + c_{t,s}\boldsymbol{\epsilon} \\ &= a_{t,s}\mathbf{x}_0 + b_{t,s}(\alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}') + c_{t,s}\boldsymbol{\epsilon} \\ &= (a_{t,s} + b_{t,s}\alpha_s)\mathbf{x}_0 + \sqrt{b_{t,s}^2\sigma_s^2 + c_{t,s}^2}\,\boldsymbol{\epsilon}'',\end{aligned} \tag{9.2.8}$$

其中 $\boldsymbol{\epsilon}, \boldsymbol{\epsilon}'$ 独立标准高斯，$\boldsymbol{\epsilon}''$ 表示归一化线性组合。为匹配目标边缘，均值与方差须满足 $\alpha_t = a_{t,s} + b_{t,s}\alpha_s$、$\sigma_t^2 = b_{t,s}^2\sigma_s^2 + c_{t,s}^2$。三个系数只有两个约束，因此转移不唯一。以 $0 \le c_{t,s} \le \sigma_t$ 为自由参数，取非负分支：

$$b_{t,s} = \frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s}, \qquad a_{t,s} = \alpha_t - \alpha_s b_{t,s}. \tag{9.2.9}$$

非负 b 对应标准 DDIM 耦合，代入得

$$\pi(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t; \alpha_t\mathbf{x}_0 + \frac{\sqrt{\sigma_t^2 - c_{t,s}^2}}{\sigma_s}(\mathbf{x}_s - \alpha_s\mathbf{x}_0), c_{t,s}^2\mathbf{I}\right). \tag{9.2.10}$$

$\mathbf{x}_s - \alpha_s\mathbf{x}_0$ 是已有噪声，c 控制新注入高斯噪声。变化 c 改变耦合而保留目标边缘。

> **注。**此核一般不同于原 Markov 正向过程的 Bayes 后验；后者只对应下述一种 c。其他选择给出不同相容耦合，$c = 0$ 为确定性 DDIM。

DDIM 采样器：一步 $s \to t$。 条件核仍依赖未知干净样本。生成时以预训练预测替代，噪声参数化下定义

$$\begin{aligned}\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s) &:= \frac{\mathbf{x}_s - \sigma_s\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_s, s)}{\alpha_s}, \\ p_{\phi^\times}(\mathbf{x}_t \mid \mathbf{x}_s) &:= \pi\big(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_{\phi^\times}(\mathbf{x}_s, s)\big), \\ \mathbf{x}_t &= \frac{\alpha_t}{\alpha_s}\mathbf{x}_s + \left(\sqrt{\sigma_t^2 - c_{t,s}^2} - \sigma_s\frac{\alpha_t}{\alpha_s}\right)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_s, s) + c_{t,s}\boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).\end{aligned}$$

模型决定携带的估计干净/噪声内容，$c \in [0, \sigma_t]$ 控制新噪声。比较原 Markov 正向过程，令 $\alpha_{s|t} := \alpha_s/\alpha_t$、$\sigma_{s|t}^2 := \sigma_s^2 - \alpha_{s|t}^2\sigma_t^2$，则 $p(\mathbf{x}_s \mid \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_s; \alpha_{s|t}\mathbf{x}_t, \sigma_{s|t}^2\mathbf{I})$，高斯条件化给出后验方差 $\mathrm{Var}(\mathbf{x}_t \mid \mathbf{x}_s, \mathbf{x}_0) = (\sigma_t^2/\sigma_s^2)\sigma_{s|t}^2\mathbf{I}$。

- **DDPM 后验方差步：** $c_{t,s} = (\sigma_t/\sigma_s)\sigma_{s|t}$，结合非负分支，条件核恰等于原过程 Bayes 后验。
- **确定性 DDIM（$\eta = 0$）：** $c = 0$ 去掉新噪声，实际更新为 $\mathbf{x}_t = (\alpha_t/\alpha_s)\mathbf{x}_s + (\sigma_t - \sigma_s\alpha_t/\alpha_s)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_s, s)$，恰与 PF-ODE 推导相同。条件层面，若 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$，则输出为 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\boldsymbol{\epsilon}$，共享同一干净样本与噪声，仅改变系数。

- **插值：**更一般地取

$$c_{t,s} = \eta \frac{\sigma_t}{\sigma_s} \sigma_{s|t}, \qquad \eta \in [0,1]. \tag{9.2.11}$$

η 连续控制随机性，0 为确定性 DDIM，1 匹配相应 DDPM Markov 转移的后验方差。

译注：上述 DDPM 比较以原正向 Markov 转移有效为前提，特别要求 $\sigma_{s|t}^2 = \sigma_s^2 - (\alpha_s/\alpha_t)^2\sigma_t^2 \geq 0$。条件核的边缘相容性是在给定真实 $\mathbf{x}_0$、输入服从指定条件边缘时成立；以网络预测代入未知 $\mathbf{x}_0$ 后，不自动保证生成边缘严格等于原扰动边缘。

所以 DDIM 族将不变的扰动边缘与可调的相邻水平耦合分离：确定性情形保留既有共享噪声，DDPM 后验选择注入原 Markov 过程规定的额外随机性。

与条件流匹配的联系。 同一条件高斯路径有有限时间映射与瞬时速度两个对象。DDIM 关联前者，CFM（第 5.2 节）建立于后者。

给定干净样本，固定 $(\mathbf{x}_0, \boldsymbol{\epsilon})$ 的 $\mathbf{x}_\tau = \alpha_\tau \mathbf{x}_0 + \sigma_\tau \boldsymbol{\epsilon}$ 是精确条件轨迹。消去共享噪声，得到精确有限映射

$$\Psi_{s\to t}(\mathbf{x}_s \mid \mathbf{x}_0) = \frac{\sigma_t}{\sigma_s}\mathbf{x}_s + \left(\alpha_t - \alpha_s \frac{\sigma_t}{\sigma_s}\right)\mathbf{x}_0.$$

这还不是实际 DDIM，因为生成时不知道干净样本；以步首预测替代它，才得到确定性更新。

无穷小时间视角则对路径求导：$d\mathbf{x}_t/dt = \alpha_t'\mathbf{x}_0 + \sigma_t'\boldsymbol{\epsilon}$。用 $\boldsymbol{\epsilon} = (\mathbf{x} - \alpha_t\mathbf{x}_0)/\sigma_t$，写为 CFM 条件速度

$$\mathbf{v}_t^*(\mathbf{x} \mid \mathbf{x}_0) = \frac{\sigma_t'}{\sigma_t}\mathbf{x} + \left(\alpha_t' - \alpha_t\frac{\sigma_t'}{\sigma_t}\right)\mathbf{x}_0.$$

在当前状态对干净样本的不确定性求后验平均，得到

$$\begin{aligned}
\mathbf{v}^*(\mathbf{x}, t) &:= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0 \mid \mathbf{x}_t = \mathbf{x})}[\mathbf{v}_t^*(\mathbf{x} \mid \mathbf{x}_0)] \\
&= \frac{\sigma_t'}{\sigma_t}\mathbf{x} + \left(\alpha_t' - \alpha_t\frac{\sigma_t'}{\sigma_t}\right)\mathbf{x}^*(\mathbf{x}, t) \\
&= \alpha_t'\mathbf{x}^*(\mathbf{x}, t) + \sigma_t'\boldsymbol{\epsilon}^*(\mathbf{x}, t),
\end{aligned}$$

其中 $\mathbf{x}^* = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t = \mathbf{x}]$，且 $\mathbf{x} = \alpha_t\mathbf{x}^* + \sigma_t\boldsymbol{\epsilon}^*$，结果恰为理想边缘 PF-ODE 速度。

> **DDIM 与 CFM。**同一条件高斯路径有两种视角：DDIM 在有限时间映射中以预测替代未知干净样本；CFM 使用瞬时条件速度，后验平均后给出边缘 PF-ODE 速度。

条件路径及瞬时速度层面的联系精确，却不意味着有限 DDIM 步为精确边缘流：DDIM 冻结步首预测，精确边缘速度则随演化状态连续变化。

9.3 DEIS

因子化指数积分式 (9.1.7) 中，权重 $g^2(\tau)E(\tau \to t)/(2\sigma_\tau)$ 全已知，唯一未知是沿轨迹的网络预测。DDIM 整步冻结步首值；预测在大步内显著变化时可能不准。

DEIS（Zhang and Chen, 2022）受 AB 等经典多步法启发，不增加本步额外求值，而复用此前已完成步骤的预测作锚点，拟合多项式，将近期变化外推到下一步。用多项式替代积分内未知预测，解析保留已知权重，从 DDIM 的常数近似扩展到高阶多步多项式近似。经典数值视角中，这是因子化指数积分框架内的 AB 式多步方法。

第 9.3.1 节回顾外推，第 9.3.2 节推导更新，第 9.3.3 节说明零次多项式恰恢复 DDIM。

9.3.1 背景：多项式外推

先穿过已知值拟合多项式，再在最近锚点之外计算，预测该量如何继续变化。因此它在锚点上是插值，在下一求解步骤区间则是外推。设已知 $n+1$ 个不同时间的值 $(\tau_j, \mathbf{Y}_j)$，$\tau_0 < \cdots < \tau_n$，$\mathbf{Y}_j$ 可为向量。唯一不超过 n 次的 Lagrange 插值多项式为

$$\mathbf{P}_n(\tau) = \sum_{j=0}^{n} \ell_j(\tau)\mathbf{Y}_j, \qquad \ell_j(\tau) := \prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{\tau - \tau_k}{\tau_j - \tau_k}.$$

每个因子使基函数在另一锚点为零，分母使其在自身锚点为 1。因此 $\ell_j(\tau_k) = \delta_{jk}$，$\mathbf{P}_n(\tau_j) = \mathbf{Y}_j$，且 $\sum_j \ell_j(\tau) = 1$。多项式是观测值的时变线性组合，在锚点精确复现，在中间或外侧描述变化所提示的局部趋势。DEIS 把同一曲线延伸到最近锚点之外。

例。

- $n = 0$（常数）：一个锚点，$\mathbf{P}_0(\tau) = \mathbf{Y}_0$，保持最近值；
- $n = 1$（线性）：两个锚点间直线，$\mathbf{P}_1(\tau) = \frac{\tau-\tau_1}{\tau_0-\tau_1}\mathbf{Y}_0 + \frac{\tau-\tau_0}{\tau_1-\tau_0}\mathbf{Y}_1$；
- $n = 2$（二次）：$\mathbf{P}_2(\tau) = \ell_0(\tau)\mathbf{Y}_0 + \ell_1(\tau)\mathbf{Y}_1 + \ell_2(\tau)\mathbf{Y}_2$，还可捕捉局部曲率。

DEIS 锚点来自此前采样步骤的网络预测，精确匹配这些储存值，再向下一个逆时间区间外推。

9.3.2 DEIS：PF-ODE 积分的 Lagrange 多项式近似

选次数 $n \geq 0$。第 i 步，用过去输出构造 n 次 Lagrange 多项式，在下一逆时间区间 $[t_i, t_{i-1}]$ 近似映射 $\tau \mapsto \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau)$，代入指数积分式得到 $\widetilde{\mathbf{x}}_{t_i}$。它利用近期历史刻画变化，而非保持常数。$n$ 次更新需 $n+1$ 个锚点。$i \geq n+1$ 时用完整次数；初始 $i \leq n$ 时只有较少历史，使用可行最高次数 $i-1$。

情形 I：$i = n+1, \ldots, M$，历史充足。 复用最近 $n+1$ 次求值，

$$(\tau_j, \mathbf{Y}_j) := \big(t_{i-1-j}, \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j})\big), \qquad j = 0, \ldots, n.$$

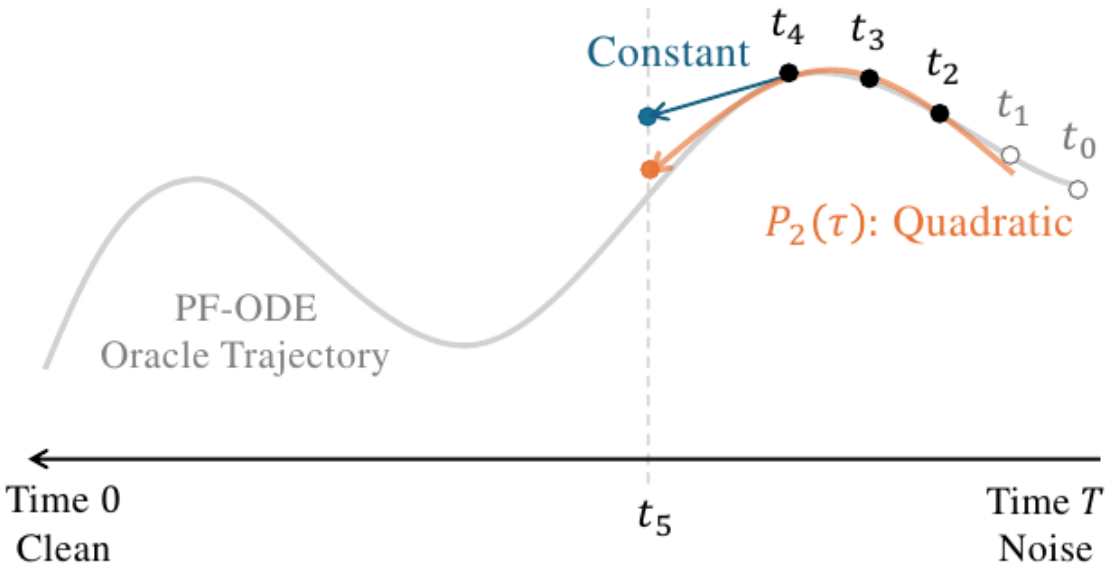


图 9.2: DEIS 多步法示意。以 t_2, t_3, t_4 的三个过去锚点构造穿过模型输出的二次曲线，外推 $t_4 \to t_5$；再对已知扩散权重积分，捕捉 DDIM 常数近似忽略的预测变化。Constant、Quadratic 依次为常数、二次。图内曲线与 PF-ODE 理想轨迹为示意，不将网络输出空间与状态轨迹混为同一对象。来源：原作者。

将沿轨迹的预测视为光滑时间函数，构造

$$\mathbf{P}_n(\tau) = \sum_{j=0}^{n} \underbrace{\left[\prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{\tau - t_{i-1-k}}{t_{i-1-j} - t_{i-1-k}}\right]}_{\ell_j^{(i)}(\tau)} \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}),$$

$$\mathbf{P}_n(\tau_j) = \mathbf{Y}_j, \qquad \ell_j^{(i)}(t_{i-1-m}) = \begin{cases} 1, & m = j, \\ 0, & m \neq j. \end{cases}$$

在新步上外推 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau) \approx \mathbf{P}_n(\tau)$，$\tau \in [t_i, t_{i-1}]$，替换积分得到

$$\begin{aligned} &\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} E(\tau \to t_i) \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_\tau, \tau) d\tau \\ &\approx \sum_{j=0}^{n} \underbrace{\left[\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} E(\tau \to t_i) \ell_j^{(i)}(\tau) d\tau\right]}_{C_{i,j}} \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}). \end{aligned}$$

$C_{i,j}$ 仅依赖调度与网格，可预计算；有适当原函数时闭式可得，否则可高精度数值计算。精确积分线性部分给出 AB-DEIS-n 更新

$$\widetilde{\mathbf{x}}_{t_i} = E(t_{i-1} \to t_i) \widetilde{\mathbf{x}}_{t_{i-1}} + \sum_{j=0}^{n} C_{i,j} \boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}).$$

以下令 h 为特征局部步长，相邻步长比有界。模型预测沿经验轨迹满足标准光滑性、调度权重正则时，完整历史 n 次构造形式阶数为 $n+1$，单步局部缺陷 $O(h^{n+2})$。

情形 II：$i = 1, \dots, n$，历史不足。 只有 i 次过去求值，利用全部锚点，取次数 $i-1$：

$$\mathbf{P}_{i-1}(\tau) = \sum_{j=0}^{i-1} \ell_j^{(i)}(\tau) \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}),$$

其中基函数在 $\{t_{i-1}, \dots, t_0\}$ 上构造。它匹配全部可用锚点，$i \geq n+1$ 后进入完整历史公式。这是多步法的标准预热：第一步常数、第二步线性、第三步二次，直至目标次数可用。

例：Lagrange 多项式的特例。 零次为 $\mathbf{P}_0(\tau) = \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1}}, t_{i-1})$，恰为 DDIM 冻结预测。一阶穿过两锚点：

$$\begin{aligned}\mathbf{P}_1(\tau) = &\underbrace{\frac{\tau - t_{i-2}}{t_{i-1} - t_{i-2}}}_{\ell_{i-1}(\tau)} \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) \\ &+ \underbrace{\frac{\tau - t_{i-1}}{t_{i-2} - t_{i-1}}}_{\ell_{i-2}(\tau)} \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-2}}, t_{i-2}).\end{aligned}$$

在两锚点分别复现对应预测，且两基权重之和为 1。

AB-DEIS-n 更新小结。 这里 AB 指在指数积分形式内应用 Adams–Bashforth 多步原则（Hochbruck and Ostermann, 2010）。[7] n 为目标多项式次数，最多使用 $n+1$ 次过去求值。令 $m_i := \min\{n, i-1\}$，合并两种情况：

$$\widetilde{\mathbf{x}}_{t_i} = E(t_{i-1} \to t_i)\widetilde{\mathbf{x}}_{t_{i-1}} + \sum_{j=0}^{m_i} C_{i,j} \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1-j}}, t_{i-1-j}),$$

$$C_{i,j} := \frac{1}{2} \int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{\sigma_\tau} E(\tau \to t_i) \left[\prod_{\substack{k=0 \\ k \neq j}}^{m_i} \frac{\tau - t_{i-1-k}}{t_{i-1-j} - t_{i-1-k}} \right] d\tau.$$

历史充足时局部误差 $O(h^{n+2})$，对应 $n+1$ 阶；预热时次数 $i-1$、单步局部误差 $O(h^{i+1})$、形式阶数 i，从 1 逐渐升至 $n+1$。低阶预热本身不能保证全局 $n+1$ 阶，还需稳定性与足够准确的起始值。

过大 n 会因高阶外推对锚点间距、存储预测误差和稳定性敏感而恶化表现，实际宜用较低次数。$n = 0$ 恰化为确定性 DDIM，即一阶因子化指数积分。

9.3.3 DDIM = AB-DEIS-0

零次多项式整步只使用最近预测，系数为 $C_{i0} = \frac{1}{2}\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{\sigma_\tau} E(\tau \to t_i) d\tau$。代入得

$$\begin{aligned}\widetilde{\mathbf{x}}_{t_i} &= E(t_{i-1} \to t_i)\widetilde{\mathbf{x}}_{t_{i-1}} + C_{i0} \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}) \\ &= e^{\int_{t_{i-1}}^{t_i} f(u)du} \widetilde{\mathbf{x}}_{t_{i-1}} \\ &\quad + \left(\int_{t_{i-1}}^{t_i} \frac{g^2(\tau)}{2\sigma_\tau} e^{\int_\tau^{t_i} f(u)du} d\tau \right) \boldsymbol{\epsilon}_{\phi\times}(\widetilde{\mathbf{x}}_{t_{i-1}}, t_{i-1}).\end{aligned} \tag{9.3.1}$$

[7] 此句对应原脚注 7；AB 名称与原书定义一致，不将次数 n 误读为数值阶数。

此式与 DDIM 保持步首预测、解析传播整步已知调度完全相同，不仅一阶等价，而是有限步更新相同。

命题 9.3.1 (DDIM = AB-DEIS-0)**.** *式 (9.3.1) 与式 (9.2.1) 的 DDIM 更新相同。*

索引 0 指多项式次数，不是数值阶数；它仍是一阶方法。高次 DEIS 保留相同解析处理，只以更多历史求值的多项式外推替换常数预测。

后面的 DPM-Solver++(2M) 从对数 SNR 时间下数据预测的局部 Taylor 展开出发，用历史后向有限差分估计导数；虽表示与推导不同，也复用过去预测捕捉变化，不增加步内阶段。第 9.5.5 节将具体比较。

9.4 DPM-Solver

DPM-Solver（Lu et al., 2022b）利用 DDIM 讨论中的扩散特有结构，为经验 PF-ODE 构造高阶求解器，目标是远少于一阶采样器的网络求值即可准确采样。原始方法针对噪声预测，构造一、二、三阶单步求解器；DPM-Solver++（Lu et al., 2022c）和 DPM-Solver-v3（Zheng et al., 2023）进一步发展此族。

高层思想。 DDIM 解析保留调度、冻结网络预测；DPM-Solver 进一步高阶近似沿轨迹的预测变化。像 DEIS 一样，它从半线性噪声形式出发，

$$\frac{d\mathbf{x}_t}{dt} = \frac{\alpha_t'}{\alpha_t}\mathbf{x}_t - \sigma_t\left(\frac{\alpha_t'}{\alpha_t} - \frac{\sigma_t'}{\sigma_t}\right)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t, t). \tag{9.4.1}$$

额外关键成分是遵循 VDM（Kingma et al., 2021）的对数 SNR 参数化，以半对数信噪比重参数化时间：

$$\lambda_t := \log\frac{\alpha_t}{\sigma_t}. \tag{9.4.2}$$

它与 DDIM 时钟 $\rho_t = e^{-\lambda_t}$ 直接相关，使模型项变为方便的指数加权积分。对 λ 作局部 Taylor 展开后可解析积分，从一阶 DDIM 系统推广至高阶。

9.4.1 DPM-Solver 的洞见：以对数 SNR 重参数化时间

PF-ODE 中的对数 SNR 换元。 设相关区间 $\alpha_t, \sigma_t > 0$，λ_t 严格单调，逆函数 t_λ 满足 $t = t_\lambda(\lambda(t))$。若 $\sigma_0 = 0$，则原文在通常数据端调度下取 $t \to 0$ 时 $\lambda_t \to +\infty$，端点公式应按相应极限，或数值实现中小正终时理解。[8]

帽号与 λ 表示重参数化时间下的量，具体定义

$$\begin{aligned}\widehat{\mathbf{x}}_\lambda &:= \mathbf{x}_{t_\lambda(\lambda)}, \quad \alpha_\lambda := \alpha_{t_\lambda(\lambda)}, \quad \sigma_\lambda := \sigma_{t_\lambda(\lambda)},\\ \widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}, \lambda) &:= \boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}, t_\lambda(\lambda)).\end{aligned} \tag{9.4.3}$$

[8]译注：这一发散还需 $\alpha_t/\sigma_t \to +\infty$；例如 $\alpha_0 > 0$、α_t 连续且 $\sigma_t \to 0^+$ 可保证它，通常采用 $\alpha_0 = 1$。仅有 $\sigma_0 = 0$ 与内部区间的正性、严格单调性不足以推出发散。端点表达仍须相应极限存在，不能直接代入零分母。

沿经验轨迹，$\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)=\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_{t_\lambda(\lambda)},t_\lambda(\lambda))$。由 $d\lambda_t/dt=\alpha_t'/\alpha_t-\sigma_t'/\sigma_t$，式 (9.4.1) 为

$$\frac{d\mathbf{x}_t}{dt}=\frac{d\log\alpha_t}{dt}\mathbf{x}_t-\sigma_t\frac{d\lambda_t}{dt}\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t,t).$$

用链式法则 $d\mathbf{x}_t/dt=(d\widehat{\mathbf{x}}_\lambda/d\lambda)(d\lambda_t/dt)$，以及 $d\log\alpha_t/dt=(d\log\alpha_\lambda/d\lambda)(d\lambda_t/dt)$，得到

$$\frac{d\widehat{\mathbf{x}}_\lambda}{d\lambda}=\frac{d\log\alpha_\lambda}{d\lambda}\widehat{\mathbf{x}}_\lambda-\sigma_\lambda\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda).\tag{9.4.4}$$

对它应用常数变易公式：

命题 9.4.1 (指数加权的精确解)**.** 给定 $s>0$ 的初值 $\mathbf{x}_s$，$t\in(0,s]$ 的精确经验 *PF-ODE* 解可写为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)=\frac{\alpha_t}{\alpha_s}\mathbf{x}_s-\alpha_t\int_{\lambda_s}^{\lambda_t}e^{-\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)d\lambda.\tag{9.4.5}$$

若 $\sigma_0=0$，$t=0$ 按相应极限解释。

证明. 线性积分因子满足 $\exp(\int_{\lambda_s}^{\lambda_t}(d\log\alpha_\lambda/d\lambda)d\lambda)=\alpha_t/\alpha_s$。因此

$$\begin{aligned}\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)&=\frac{\alpha_t}{\alpha_s}\mathbf{x}_s-\int_{\lambda_s}^{\lambda_t}\frac{\alpha_t}{\alpha_\lambda}\sigma_\lambda\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)d\lambda\\&=\frac{\alpha_t}{\alpha_s}\mathbf{x}_s-\alpha_t\int_{\lambda_s}^{\lambda_t}e^{-\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)d\lambda,\end{aligned}$$

最后使用 $\sigma_\lambda/\alpha_\lambda=e^{-\lambda}$。 □

λ 时间下，模型相关量只出现在指数加权积分中。将预测局部近似为 λ 的 Taylor 多项式，所有加权多项式项均可闭式积分，给出显式高阶系数。调度仍解析处理，近似集中于预测。

为何重参数化时间的直觉。 局部一阶换元给出 $|\Delta t|\approx|\Delta\lambda|/|\lambda'(t)|$。固定 $|\Delta\lambda|$ 时，$|\lambda'|$ 大处原时间步小，反之步大。重参数化不改变解路径，只改变进度标记：$d\widehat{\mathbf{x}}_\lambda/d\lambda=(1/\lambda'(t))d\mathbf{x}_t/dt$。所以 $|\lambda'|$ 大时，同样的原时间轨迹变化被摊在较大 λ 区间上。

更关键的是，λ 用信号与噪声相对平衡衡量进度；固定增量对应 α_t/σ_t 固定乘法变化、对数 SNR 固定加法变化，而同一 Δt 在不同时间可代表很不同的污染变化。均匀 λ 网格自然重新分配分辨率，具体 t 间距依调度。例如：

- $(\alpha_t,\sigma_t)=(1-t,t)$ 是流匹配常用线性插值，$\lambda(t)=\log((1-t)/t)$、$\lambda'(t)=-1/[t(1-t)]$，所以 $|\Delta t|\approx|\Delta\lambda|t(1-t)$。两端步很小，中间较大。

- $(\alpha_t,\sigma_t)=(1,t)$ 对应以噪声水平本身为自变量的 EDM 参数化（Karras et al., 2022），$\lambda=\log(1/t)$、$\lambda'=-1/t$，所以 $|\Delta t|\approx|\Delta\lambda|t$。实际 $t=e^{-\lambda}$，均匀 λ 使噪声水平几何间隔；小噪声处绝对间距细，大噪声处粗。

9.4.2 以 Taylor 展开估计积分

DEIS 与 DPM-Solver 使用同一因子化原则，但高阶信息来源不同：前者复用已完成步骤外推，后者在 λ 中局部 Taylor 展开，从本步额外求值取得所需信息。

从当前数值状态 $\widetilde{\mathbf{x}}_s$ 初始化的精确经验流为

$$\widetilde{\Psi}_{s\to t}(\widetilde{\mathbf{x}}_s)=\frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s-\alpha_t\int_{\lambda_s}^{\lambda_t}e^{-\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)d\lambda, \tag{9.4.6}$$

$\widehat{\mathbf{x}}_{\lambda_s}=\widetilde{\mathbf{x}}_s$，$\widehat{\mathbf{x}}_\lambda$ 是本步精确经验轨迹。对 $n\geq 1$，展开

$$\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)=\sum_{k=0}^{n-1}\frac{(\lambda-\lambda_s)^k}{k!}\widehat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)+O((\lambda-\lambda_s)^n),$$
$$\widehat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda):=\frac{d^k}{d\lambda^k}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda).$$

导数是沿经验轨迹的全导数，包含显式时间依赖与经状态演化的依赖：

$$\frac{d}{d\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)=\frac{\partial}{\partial\lambda}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)+\mathbf{J}_{\mathbf{x}}\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)\frac{d\widehat{\mathbf{x}}_\lambda}{d\lambda}.$$

代入得

$$\widetilde{\Psi}_{s\to t}(\widetilde{\mathbf{x}}_s)=\frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s-\alpha_t\sum_{k=0}^{n-1}\widehat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)C_k+O(h^{n+1}), \tag{9.4.7}$$

$h:=\lambda_t-\lambda_s$，$C_k:=\int_{\lambda_s}^{\lambda_t}e^{-\lambda}(\lambda-\lambda_s)^k/k!\,d\lambda$。系数仅依赖对数 SNR 区间，可解析求得。若导数已知，丢弃余项给出形式 n 阶更新；DPM-Solver 用额外模型求值近似导数，避免显式微分网络。

例：DPM-Solver-1。 对 $n=1$，精确流为 $\frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s-\sigma_t(e^h-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s)+O(h^2)$。丢弃余项定义

$$\widetilde{\mathbf{x}}_t^{\text{DPM-Solver-1}}:=\frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s-\sigma_t(e^h-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s). \tag{9.4.8}$$

有限步恰等于 DDIM。$n\geq 2$ 需至 $n-1$ 阶导数，直接计算昂贵，Lu et al. (2022b) 给出下节的高效近似。

9.4.3 DPM-Solver-n 的实现

实际高阶实现需要预计算 C_k，并近似高阶导数以绕开直接求导成本。这是 ODE 文献中的成熟问题（Hochbruck and Ostermann, 2005; Luan, 2021），有限差分是常见策略。

预计算 C_k。 令 $h=\lambda_t-\lambda_s$，Taylor 式可写为

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)=\frac{\alpha_t}{\alpha_s}\mathbf{x}_s-\sigma_t\sum_{k=0}^{n-1}h^{k+1}\varphi_{k+1}(h)\widehat{\boldsymbol{\epsilon}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)+O(h^{n+1}), \tag{9.4.9}$$

对 $m\geq 1$，

$$\varphi_m(h):=\frac{e^h-\sum_{j=0}^{m-1}h^j/j!}{h^m},\qquad \varphi_m(0):=\frac{1}{m!},$$
$$\varphi_1(h)=\frac{e^h-1}{h},\quad \varphi_2(h)=\frac{e^h-h-1}{h^2},\quad \varphi_3(h)=\frac{e^h-h^2/2-h-1}{h^3}.$$

例：精确导数的三阶展开。 取 $n=3$，

$$\begin{aligned}\widetilde{\Psi}_{s\to t}(\mathbf{x}_s) = \frac{\alpha_t}{\alpha_s}\mathbf{x}_s &- \sigma_t(e^h-1)\widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)\\ &- \sigma_t(e^h-h-1)\widehat{\boldsymbol{\epsilon}}^{(1)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)\\ &- \sigma_t(e^h-h^2/2-h-1)\widehat{\boldsymbol{\epsilon}}^{(2)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)+O(h^4).\end{aligned} \tag{9.4.10}$$

近似所需导数。 $n\geq 2$ 时，依单步 ODE 求解的标准方式（Atkinson et al., 2009），在本步增加模型求值。以 $n=2$ 为例，固定 $\gamma\in(0,1]$，令 $s_{\mathrm{mid}}:=t_\lambda(\lambda_s+\gamma h)$。$\gamma<1$ 是内部阶段，$\gamma=1$ 为终点 t。先以 DPM-Solver-1 预测阶段状态

$$\mathbf{x}_{\mathrm{mid}} = \frac{\alpha_{s_{\mathrm{mid}}}}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_{s_{\mathrm{mid}}}(e^{\gamma h}-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s),$$

再以阶段与步首预测差近似全导数：

$$\widehat{\boldsymbol{\epsilon}}^{(1)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_s},\lambda_s)\approx\frac{\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_{\mathrm{mid}},s_{\mathrm{mid}})-\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s)}{\gamma h}.$$

代入二阶展开得

$$\begin{aligned}\widetilde{\Psi}_{s\to t}(\widetilde{\mathbf{x}}_s) = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s &- \sigma_t(e^h-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s)\\ &- \frac{\sigma_t}{\gamma h}(e^h-h-1)[\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_{\mathrm{mid}},s_{\mathrm{mid}})-\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_s,s)]+O(h^3).\end{aligned} \tag{9.4.11}$$

舍弃余项即二阶单步法。取中点 $\gamma=1/2$ 时可用算法 5 的简化两阶段形式，与上式仅差 $O(h^3)$，仍二阶。

算法 5 DPM-Solver-2（$\gamma=1/2$）

Require: 初值 $\mathbf{x}_T$，时间步 $\{t_i\}_{i=0}^M$，模型 $\boldsymbol{\epsilon}_{\phi^\times}$

$\widetilde{\mathbf{x}}_{t_0}\leftarrow\mathbf{x}_T$
for $i=1,\dots,M$ **do**
  $h_i\leftarrow\lambda_{t_i}-\lambda_{t_{i-1}}$
  $s_i^{\mathrm{mid}}\leftarrow t_\lambda((\lambda_{t_{i-1}}+\lambda_{t_i})/2)$
  $\mathbf{x}_i^{\mathrm{mid}}\leftarrow\frac{\alpha_{s_i^{\mathrm{mid}}}}{\alpha_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}-\sigma_{s_i^{\mathrm{mid}}}(e^{h_i/2}-1)\boldsymbol{\epsilon}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1}},t_{i-1})$
  $\widetilde{\mathbf{x}}_{t_i}\leftarrow\frac{\alpha_{t_i}}{\alpha_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}-\sigma_{t_i}(e^{h_i}-1)\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_i^{\mathrm{mid}},s_i^{\mathrm{mid}})$
end for
return $\widetilde{\mathbf{x}}_{t_M}$

注。有限差分近似沿经验轨迹的全 λ 导数。标准光滑性下，上述商等于精确一阶导数加 $O(h)$。阶段由一阶法得到、状态误差 $O(h^2)$，模型光滑时不改变差分商的 $O(h)$ 精度。式 (9.4.11) 中导数近似乘 $e^h-h-1=O(h^2)$，诱导 $O(h^3)$ 误差，因此任意固定 $\gamma\in(0,1]$ 均二阶。共两次求值：步首与预测阶段。γ 不改变形式阶数，但改变阶段位置和误差常数；$1/2$ 给出常用中点版本。

实现细节：采样时间步选择。 局部高阶近似在 λ 中构造，均匀 λ 节点是自然选择。有限终时 $t_M > 0$ 时，

$$\lambda_{t_i} = \lambda_{t_0} + \frac{i}{M}(\lambda_{t_M} - \lambda_{t_0}), \qquad i = 0, \dots, M.$$

若 $\sigma_0 = 0$、$\lambda_0 = +\infty$，实际用小正终时对应的有限终端对数 SNR，端点由极限或最后去噪步处理。虽然推导在 λ 空间，预训练网络和调度通常以原时间为参数；每次模型求值或需要系数时，通过 $t_i = t_\lambda(\lambda_{t_i})$ 映回原标签。λ 是积分坐标，不改变原模型输入时间约定。

9.4.4 DDIM = DPM-Solver-1

二者从同一噪声 PF-ODE 精确积分式出发，整步冻结同一预测，解析积分剩余调度。DDIM 直接在调度对齐形式推导，DPM-Solver 先换到 λ；一阶常数近似不因换时钟改变，因而有限更新精确相同。

命题 9.4.2 (DDIM 就是 DPM-Solver-1)**.** *固定扩散调度 (α_t, σ_t) 后，式 (9.2.1) 的确定性 DDIM 与式 (9.4.8) 相同。*

证明. $\sigma_s/\alpha_s = e^{-\lambda_s}$、$\sigma_t/\alpha_t = e^{-\lambda_t}$，所以 $e^h = \alpha_t\sigma_s/(\sigma_t\alpha_s)$。于是

$$-\sigma_t(e^h - 1) = \sigma_t - \sigma_s\frac{\alpha_t}{\alpha_s} = \alpha_t\left(\frac{\sigma_t}{\alpha_t} - \frac{\sigma_s}{\alpha_s}\right).$$

代入式 (9.4.8) 即为 DDIM。 □

所以二者是同一一阶有限更新的两种推导。对数 SNR 坐标从高阶才产生实质作用：高阶法在其中近似沿轨迹的噪声预测变化，而非整步冻结。

9.4.5 DPM-Solver 与 Runge–Kutta 类求解器的关系

高阶 DPM-Solver 如何改进一次求值更新？其联系是 RK 的步内阶段原则。Euler 只用步首场，RK 在本步产生的时间与状态上额外求值；高阶 DPM-Solver 也如此，但先解析保留已知调度，仅对学习预测作分阶段近似。

DPM-Solver-2 与普通中点 RK2。 将式 (9.4.4) 的完整右端记为 $\mathbf{F}(\widehat{\mathbf{x}}_\lambda, \lambda)$，令 $\lambda_{\mathrm{mid}} = \lambda_s + h/2$、$\alpha_{\mathrm{mid}} = \alpha_{s_{\mathrm{mid}}}$、$\sigma_{\mathrm{mid}} = \sigma_{s_{\mathrm{mid}}}$，$\widehat{\boldsymbol{\epsilon}}_s := \widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\widetilde{\mathbf{x}}_s, \lambda_s)$。经典中点 RK2 为

$$\mathbf{x}_{\mathrm{mid}}^{\mathrm{RK}} = \widetilde{\mathbf{x}}_s + \frac{h}{2}\mathbf{F}(\widetilde{\mathbf{x}}_s, \lambda_s),$$
$$\widetilde{\mathbf{x}}_t^{\mathrm{RK2}} = \widetilde{\mathbf{x}}_s + h\mathbf{F}(\mathbf{x}_{\mathrm{mid}}^{\mathrm{RK}}, \lambda_{\mathrm{mid}}).$$

两阶段作用于完整速度，包括调度和神经预测。DPM-Solver-2 则为

$$\mathbf{x}_{\mathrm{mid}}^{\mathrm{DPM2}} = \frac{\alpha_{\mathrm{mid}}}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_{\mathrm{mid}}(e^{h/2} - 1)\widehat{\boldsymbol{\epsilon}}_s,$$
$$\widehat{\boldsymbol{\epsilon}}_{\mathrm{mid}}^{\mathrm{DPM2}} := \widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_{\mathrm{mid}}^{\mathrm{DPM2}}, \lambda_{\mathrm{mid}}),$$
$$\widetilde{\mathbf{x}}_t^{\mathrm{DPM2}} = \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \sigma_t(e^h - 1)\widehat{\boldsymbol{\epsilon}}_{\mathrm{mid}}^{\mathrm{DPM2}}.$$

标准光滑性下，同一经验 ODE 的两法均二阶，中间状态通常相差 $O(h^2)$，完整单步相差 $O(h^3)$。DPM-Solver 遵循同样两阶段原则，但先利用已知扩散结构。

DPM-Solver-2 与指数中点 RK2。 更接近的比较是显式保留半线性分解，解析处理线性部分。指数中点 RK2 先以指数 Euler 得到中点阶段：

$$\begin{aligned}
\mathbf{x}_{\text{mid}}^{\text{ExpRK}} &= \frac{\alpha_{\text{mid}}}{\alpha_s}\widetilde{\mathbf{x}}_s - \alpha_{\text{mid}}\sigma_s\left[\int_{\lambda_s}^{\lambda_{\text{mid}}}\frac{1}{\alpha_\lambda}d\lambda\right]\widehat{\boldsymbol{\epsilon}}_s,\\
\widehat{\boldsymbol{\epsilon}}_{\text{mid}}^{\text{ExpRK}} &:= \widehat{\boldsymbol{\epsilon}}_{\phi^\times}(\mathbf{x}_{\text{mid}}^{\text{ExpRK}}, \lambda_{\text{mid}}),\\
\widetilde{\mathbf{x}}_t^{\text{ExpRK2}} &= \frac{\alpha_t}{\alpha_s}\widetilde{\mathbf{x}}_s - \alpha_t\sigma_{\text{mid}}\left[\int_{\lambda_s}^{\lambda_t}\frac{1}{\alpha_\lambda}d\lambda\right]\widehat{\boldsymbol{\epsilon}}_{\text{mid}}^{\text{ExpRK}}.
\end{aligned}$$

线性系数恒定时，积分系数化为显式指数中点 RK2 通常的 φ_1 系数。DPM-Solver-2 采用同一中点原则，但进一步把已知 σ_λ 从残差 $-\sigma_\lambda\widehat{\boldsymbol{\epsilon}}$ 中分离，保留在积分内，仅对网络分阶段。其系数为

$$\begin{aligned}
\alpha_{\text{mid}}\int_{\lambda_s}^{\lambda_{\text{mid}}}\frac{\sigma_\lambda}{\alpha_\lambda}d\lambda &= \sigma_{\text{mid}}(e^{h/2}-1),\\
\alpha_t\int_{\lambda_s}^{\lambda_t}\frac{\sigma_\lambda}{\alpha_\lambda}d\lambda &= \sigma_t(e^{h}-1),
\end{aligned}$$

恢复算法 5。三者依次对完整速度、系数加权残差、单独神经预测作阶段近似。两种指数阶段之差

$$\mathbf{x}_{\text{mid}}^{\text{DPM2}} - \mathbf{x}_{\text{mid}}^{\text{ExpRK}} = -\alpha_{\text{mid}}\left[\int_{\lambda_s}^{\lambda_{\text{mid}}}\frac{\sigma_\lambda-\sigma_s}{\alpha_\lambda}d\lambda\right]\widehat{\boldsymbol{\epsilon}}_s = O(h^2).$$

完整步在中点展开，$\int_{\lambda_s}^{\lambda_t}(\sigma_\lambda-\sigma_{\text{mid}})/\alpha_\lambda\,d\lambda = O(h^3)$，模型光滑性还给出 $\widehat{\boldsymbol{\epsilon}}_{\text{mid}}^{\text{DPM2}}-\widehat{\boldsymbol{\epsilon}}_{\text{mid}}^{\text{ExpRK}} = O(h^2)$。因此完整更新相差 $O(h^3)$，二阶一致，但 DPM-Solver 额外解析保留 σ_λ。

> **注**。以上针对噪声预测。若预训练模型用其他参数化，可每个阶段逐点转换为噪声预测；不要混同为直接对原预测场应用经典 RK，逐点转换与有限步离散是不同操作。

> **DPM-Solver 与 RK**。DPM-Solver 结合 RK 步内阶段原则与已知扩散动力学的解析处理。一阶恰为 DDIM，高阶增加步内求值以捕捉预测变化；与经典 RK 的联系是结构上的，不是有限步公式相等。

9.5 DPM-Solver++

9.5.1 从 DPM-Solver 到用于引导采样的 DPM-Solver++

DPM-Solver++（Lu et al., 2022c）旨在改善强引导下的高阶采样。此时有两个困难：大引导尺度放大模型输出及其导数，缩小高阶法收敛区域，需要更小步长；引导预测还可能把最终解推至训练数据表示范围外，造成第 八章的训练–测试不匹配。

它采用互补对策：用数据预测改写 ODE，使动态阈值等数据空间修正可用；构造复用历史求值的多步法，在固定 NFE 下采用更多、更小的有效时间步。下面先推导数据预测形式，再介绍二阶单步和多步法。

9.5.2 DPM-Solver++ 的方法

保留 λ 坐标，将噪声预测转换为数据预测。式 (6.3.1) 给出 $\boldsymbol{\epsilon}_{\phi^\times}(\mathbf{x}_t,t)=[\mathbf{x}_t-\alpha_t\mathbf{x}_{\phi^\times}(\mathbf{x}_t,t)]/\sigma_t$。代入精确流，得到等价形式

$$\widetilde{\Psi}_{s\to t}(\mathbf{x}_s)=\frac{\sigma_t}{\sigma_s}\mathbf{x}_s+\sigma_t\int_{\lambda_s}^{\lambda_t}e^{\lambda}\widehat{\mathbf{x}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)d\lambda, \tag{9.5.1}$$

其中 $\widehat{\mathbf{x}}_{\phi^\times}(\mathbf{x},\lambda):=\mathbf{x}_{\phi^\times}(\mathbf{x},t_\lambda(\lambda))$，沿轨迹即 $\mathbf{x}_{\phi^\times}(\mathbf{x}_{t_\lambda(\lambda)},t_\lambda(\lambda))$。它与 DPM-Solver 结构对偶：解析处理已知演化，积分内模型相关量改为数据预测。二阶实现分为：

- **DPM-Solver++(2S) 单步：**像 DPM-Solver-2 一样，在本步增加中间阶段求值；
- **DPM-Solver++(2M) 多步：**复用最近两次已完成步骤的数据预测，预热后每步仅一次新求值。

  注。不加阈值时，转为数据预测只是同一经验 ODE 的逐点代数重写；数值方法仍可不同，因为有限步近似改为作用于数据而非噪声预测。阈值化则额外修改模型输出，应与下文数值阶数分析分开。

9.5.3 通过 Taylor 展开构造单步法

沿经验轨迹定义全导数 $\widehat{\mathbf{x}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda):=\frac{d^k}{d\lambda^k}\widehat{\mathbf{x}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)$。一步 $t_{i-1}\to t_i$，$h_i:=\lambda_{t_i}-\lambda_{t_{i-1}}>0$，在步首展开

$$\widehat{\mathbf{x}}_{\phi^\times}(\widehat{\mathbf{x}}_\lambda,\lambda)=\sum_{k=0}^{n-1}\frac{(\lambda-\lambda_{t_{i-1}})^k}{k!}\widehat{\mathbf{x}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_{t_{i-1}}},\lambda_{t_{i-1}})+O((\lambda-\lambda_{t_{i-1}})^n).$$

代入式 (9.5.1)，

$$\begin{aligned}\widetilde{\Psi}_{t_{i-1}\to t_i}(\widetilde{\mathbf{x}}_{t_{i-1}})=&\frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}\\&+\alpha_{t_i}\sum_{k=0}^{n-1}h_i^{k+1}\varphi_{k+1}(-h_i)\widehat{\mathbf{x}}^{(k)}_{\phi^\times}(\widehat{\mathbf{x}}_{\lambda_{t_{i-1}}},\lambda_{t_{i-1}})+O(h_i^{n+1}).\end{aligned} \tag{9.5.2}$$

这里 φ_m 与式 (9.4.9) 相同，利用了

$$\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}}e^{\lambda}\frac{(\lambda-\lambda_{t_{i-1}})^k}{k!}d\lambda=e^{\lambda_{t_i}}h_i^{k+1}\varphi_{k+1}(-h_i),\qquad\sigma_{t_i}e^{\lambda_{t_i}}=\alpha_{t_i}.$$

$n=1$ 舍弃余项，记 $\mathbf{D}_{i-1}:=\mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_{i-1}},t_{i-1})$，则

$$\widetilde{\mathbf{x}}_{t_i}=\frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}+\alpha_{t_i}(1-e^{-h_i})\mathbf{D}_{i-1},$$

恰为数据形式 DDIM。$n=2$ 时，用额外步内阶段近似一阶全导数。中点选择 $s_i^{\mathrm{mid}}:=t_\lambda(\lambda_{t_{i-1}}+h_i/2)$，先一阶预测

$$\begin{aligned}\mathbf{u}_i&=\frac{\sigma_{s_i^{\mathrm{mid}}}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}+\alpha_{s_i^{\mathrm{mid}}}(1-e^{-h_i/2})\mathbf{D}_{i-1},\\\mathbf{D}_i^{\mathrm{mid}}&:=\mathbf{x}_{\phi^\times}(\mathbf{u}_i,s_i^{\mathrm{mid}}),\\\widetilde{\mathbf{x}}_{t_i}&=\frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}}+\alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i^{\mathrm{mid}}.\end{aligned}$$

此简化两阶段更新与直接 Taylor/差分构造仅差 $O(h_i^3)$，保持二阶，是 DPM-Solver-2 的数据预测对应。实现见算法 6。

算法 6 DPM-Solver++(2S)：中点特例

Require: 初值 $\mathbf{x}_T$，时间网格 $\{t_i\}_{i=0}^{M}$，数据预测模型 $\mathbf{x}_{\phi^\times}$

$\widetilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$
对 $i = 0, \dots, M$，$\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$
$\mathbf{D}_0 \leftarrow \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_0}, t_0)$ ▷ 缓存步首预测
for $i = 1, \dots, M$ **do**
  $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$
  $s_i^{\mathrm{mid}} \leftarrow t_\lambda((\lambda_{t_{i-1}} + \lambda_{t_i})/2)$
  $\mathbf{u}_i \leftarrow \dfrac{\sigma_{s_i^{\mathrm{mid}}}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{s_i^{\mathrm{mid}}}(1 - e^{-h_i/2})\mathbf{D}_{i-1}$ ▷ 预测中点
  $\mathbf{D}_i^{\mathrm{mid}} \leftarrow \mathbf{x}_{\phi^\times}(\mathbf{u}_i, s_i^{\mathrm{mid}})$ ▷ 中点求值
  $\widetilde{\mathbf{x}}_{t_i} \leftarrow \dfrac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1 - e^{-h_i})\mathbf{D}_i^{\mathrm{mid}}$
  if $i < M$ **then**
    $\mathbf{D}_i \leftarrow \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_i}, t_i)$ ▷ 为下一步缓存
  end if
end for
return $\widetilde{\mathbf{x}}_{t_M}$

9.5.4 通过复用历史构造多步法

2S 增加步内求值获得二阶信息；2M 从此前已完成步骤复用预测，估计同一局部变化。初始化后每步只需一次新求值，同 NFE 可采用更多、更小步骤，尤其适合强引导下大步降低稳定性的情况。

二阶展开需要当前数据预测及其一阶全 λ 导数。单步以新阶段估计，多步以近期历史估计。首步无历史，以数据 DDIM 初始化：

$$\widetilde{\mathbf{x}}_{t_1} = \frac{\sigma_{t_1}}{\sigma_{t_0}}\widetilde{\mathbf{x}}_{t_0} + \alpha_{t_1}(1 - e^{-h_1})\mathbf{D}_0, \qquad \mathbf{D}_0 := \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_{t_0}, t_0).$$

$i \geq 2$ 时，已有 $\mathbf{D}_{i-1}, \mathbf{D}_{i-2}$，保留 Taylor 前两项：

$$\begin{aligned}\widetilde{\Psi}_{t_{i-1}\to t_i}(\widetilde{\mathbf{x}}_{t_{i-1}}) = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1 - e^{-h_i})\mathbf{D}_{i-1} \\ + \alpha_{t_i}(h_i - 1 + e^{-h_i})\widehat{\mathbf{x}}_{\phi^\times}^{(1)}(\widehat{\mathbf{x}}_{\lambda_{t_{i-1}}}, \lambda_{t_{i-1}}) + O(h_i^3).\end{aligned}$$

以历史后向差分 $(\mathbf{D}_{i-1} - \mathbf{D}_{i-2})/h_{i-1}$ 近似全导数，标准光滑性下误差 $O(h_{i-1})$。收集项得

$$\widetilde{\mathbf{x}}_{t_i}^{\mathrm{poly}} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1 - e^{-h_i})\mathbf{D}_i^{\mathrm{poly}},$$

$$\mathbf{D}_i^{\mathrm{poly}} := \mathbf{D}_{i-1} + \frac{\beta(h_i)}{h_{i-1}}(\mathbf{D}_{i-1} - \mathbf{D}_{i-2}), \qquad \beta(h) := \frac{h - 1 + e^{-h}}{1 - e^{-h}}.$$

相邻步长比有界时，单步局部缺陷 $O(h_i^3)$。

实际 DPM-Solver++(2M) 更新。 以上已是有效二阶多步构造。利用 $\beta(h) = h/2 + h^2/12 + O(h^3)$，令 $r_i := h_i/h_{i-1}$，以更简单系数替代：

$$\mathbf{D}_i^{\mathrm{sim}} := \mathbf{D}_{i-1} + \frac{r_i}{2}(\mathbf{D}_{i-1} - \mathbf{D}_{i-2}) = \left(1 + \frac{r_i}{2}\right)\mathbf{D}_{i-1} - \frac{r_i}{2}\mathbf{D}_{i-2}.$$

最近两预测给出局部变化方向，此量将趋势外推到本步。相同光滑性和步长比假设下，$\mathbf{D}_i^{\mathrm{poly}} - \mathbf{D}_i^{\mathrm{sim}} = O(h_i^2)$，乘以 $\alpha_{t_i}(1-e^{-h_i}) = O(h_i)$，只改变状态更新 $O(h_i^3)$，故保持二阶：

$$\widetilde{\mathbf{x}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i^{\mathrm{sim}}.$$

计算新状态后，只需一次模型求值 $\mathbf{D}_i = \mathbf{x}_{\phi\times}(\widetilde{\mathbf{x}}_{t_i}, t_i)$，缓存供下一步使用。

> **注**。均匀对数 SNR 步时，$r_i = 1$，$\mathbf{D}_i^{\mathrm{sim}} = \frac{3}{2}\mathbf{D}_{i-1} - \frac{1}{2}\mathbf{D}_{i-2}$，是熟悉的 AB2 外推权重。但完整更新不是普通 AB2，因为解析保留扩散因子 $\alpha_{t_i}(1-e^{-h_i})$。

算法 7 总结预热和两步过程。与 2S 的关键区别是二阶信息来源：2S 来自本步额外阶段，2M 来自之前已完成步骤。

算法 7 DPM-Solver++(2M)

Require: 初值 $\mathbf{x}_T$，时间网格 $\{t_i\}_{i=0}^M$，数据预测模型 $\mathbf{x}_{\phi\times}$

$\widetilde{\mathbf{x}}_{t_0} \leftarrow \mathbf{x}_T$
对 $i = 0, \dots, M$，$\lambda_{t_i} \leftarrow \log(\alpha_{t_i}/\sigma_{t_i})$
$\mathbf{D}_0 \leftarrow \mathbf{x}_{\phi\times}(\widetilde{\mathbf{x}}_{t_0}, t_0)$ ▷ 缓存步首预测
情形 I：预热（$i = 1$）
$h_1 \leftarrow \lambda_{t_1} - \lambda_{t_0}$
$\widetilde{\mathbf{x}}_{t_1} \leftarrow \frac{\sigma_{t_1}}{\sigma_{t_0}}\widetilde{\mathbf{x}}_{t_0} + \alpha_{t_1}(1-e^{-h_1})\mathbf{D}_0$ ▷ 数据 DDIM
if $M > 1$ **then**
    $\mathbf{D}_1 \leftarrow \mathbf{x}_{\phi\times}(\widetilde{\mathbf{x}}_{t_1}, t_1)$ ▷ 多步缓存
end if
情形 II：两步更新（$i \geq 2$）
for $i = 2, \dots, M$ **do**
    $h_i \leftarrow \lambda_{t_i} - \lambda_{t_{i-1}}$
    $r_i \leftarrow h_i/h_{i-1}$ ▷ 步长比
    $\mathbf{D}_i^{\mathrm{sim}} \leftarrow (1 + r_i/2)\mathbf{D}_{i-1} - (r_i/2)\mathbf{D}_{i-2}$
    $\widetilde{\mathbf{x}}_{t_i} \leftarrow \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1-e^{-h_i})\mathbf{D}_i^{\mathrm{sim}}$
    if $i < M$ **then**
        $\mathbf{D}_i \leftarrow \mathbf{x}_{\phi\times}(\widetilde{\mathbf{x}}_{t_i}, t_i)$ ▷ 一次新求值，缓存
    end if
end for
return $\widetilde{\mathbf{x}}_{t_M}$

9.5.5 DPM-Solver++(2M) 与 DEIS 的关系

两者共享多步思想：复用已完成步骤的预测，近似下一段变化，同时解析保留扩散权重。区别是表示：前面 DEIS 在原时间中用噪声预测，2M 在对数 SNR 时间中用数据预测。

为直接展示联系，将 DEIS 多项式原则应用到式 (9.5.1) 的数据积分。已知权重 e^{λ} 已解析处理，只需近似数据预测。用最近缓存 $\mathbf{D}_{i-2}, \mathbf{D}_{i-1}$ 作唯一仿射多项式，Lagrange 形式与后向

Newton 形式为

$$\begin{aligned}\mathbf{P}_1(\lambda) &= \frac{\lambda-\lambda_{t_{i-2}}}{h_{i-1}}\mathbf{D}_{i-1} - \frac{\lambda-\lambda_{t_{i-1}}}{h_{i-1}}\mathbf{D}_{i-2}\\ &= \mathbf{D}_{i-1} + \frac{\lambda-\lambda_{t_{i-1}}}{h_{i-1}}(\mathbf{D}_{i-1}-\mathbf{D}_{i-2}).\end{aligned}$$

它们是同一两锚点外推的两种表示，不是不同近似。代入积分得

$$\widetilde{\mathbf{x}}^{\mathrm{poly}}_{t_i} = \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \sigma_{t_i}\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda}\mathbf{P}_1(\lambda)d\lambda.$$

两个已知矩可精确求出：

$$\sigma_{t_i}\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda}d\lambda = \alpha_{t_i}(1-e^{-h_i}),$$

$$\sigma_{t_i}\int_{\lambda_{t_{i-1}}}^{\lambda_{t_i}} e^{\lambda}(\lambda-\lambda_{t_{i-1}})d\lambda = \alpha_{t_i}(h_i-1+e^{-h_i}).$$

所以

$$\begin{aligned}\widetilde{\mathbf{x}}^{\mathrm{poly}}_{t_i} &= \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1-e^{-h_i})\mathbf{D}_{i-1}\\ &\quad + \alpha_{t_i}(h_i-1+e^{-h_i})\frac{\mathbf{D}_{i-1}-\mathbf{D}_{i-2}}{h_{i-1}}\\ &= \frac{\sigma_{t_i}}{\sigma_{t_{i-1}}}\widetilde{\mathbf{x}}_{t_{i-1}} + \alpha_{t_i}(1-e^{-h_i})\mathbf{D}^{\mathrm{poly}}_i.\end{aligned}$$

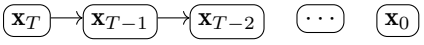
这给出精确联系：实践系数简化前，二阶多步 DPM-Solver++ 恰为对数据预测/对数 SNR 积分应用一次 DEIS 外推原则的结果，即 AB-DEIS-1 的数据/对数 SNR 对应。

实践 2M 再以 $\beta(h_i) = h_i/2 + O(h_i^2)$，将 $\beta(h_i)/h_{i-1}$ 替为 $h_i/(2h_{i-1})$，系数差 $O(h_i^2/h_{i-1})$。因为 $\mathbf{D}_{i-1}-\mathbf{D}_{i-2} = O(h_{i-1})$，有效预测差为 $O(h_i^2)$，乘状态系数 $O(h_i)$，只改更新 $O(h_i^3)$。所以 2M 与加权一次多项式更新通常是不同有限步公式，但二阶一致。联系特指 2M：它外推历史，2S 则用新中间阶段。完整预热和缓存见算法 7。

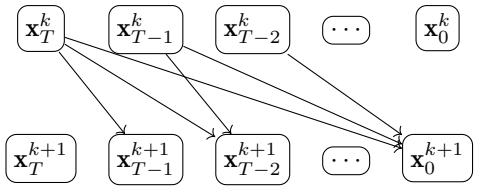
9.5.6 结束评论

DPM-Solver 以噪声预测推导，DPM-Solver++ 以数据预测改写，强 CFG 下可能更有利。DPM-Solver-v3（Zheng et al., 2023）进一步用更一般模型表示，系数由预计算模型统计选取，以减少局部离散误差，使表示本身成为设计的一部分。

相关方向是预测–校正框架：得分 SDE 中，预测器以逆时间数值步推进，校正器通常在相同噪声水平用 Langevin 式得分更新进一步细化（原第 3.4 节）。该“先预测再细化”也有经典类比，如 Heun 先 Euler 预测端点，再以平均斜率改善更新。UniPC（原引文键 `zhao2023unipc`）构造扩散专用预测–校正。这里不进一步展开，它们仍体现本章主题：有效求解器将经典数值思想与扩散 PF-ODE 特有结构结合。



（a）生成过程按时间步顺序估计。



（b）含跳跃依赖的 Picard 迭代。

图 9.3: 两种计算图。左：传统时间步 ODE 求解，按时间顺序传播解。右：Picard 利用上次迭代结果同时更新所有时间节点，使时间计算并行，避免严格顺序依赖。按源图 6 条跨层依赖与锚点无入箭头结构重建为 tikzcd；省略号保持原示意。来源：改编自 Shih et al. (2023)。

9.6 （可选）ParaDiGMs

9.6.1 从时间步进到时间并行求解器

前面从先验时刻 T 逐步向任意 $t \in [0,T]$ 估计轨迹。设经验 PF-ODE 漂移为 $\mathbf{v}_{\phi^\times}(\mathbf{x},t) := \mathbf{f}(\mathbf{x},t) - \frac{1}{2}g^2(t)\mathbf{s}_{\phi^\times}(\mathbf{x},t)$，精确演化为

$$\widetilde{\Psi}_{T\to t}(\mathbf{x}(T)) = \mathbf{x}(T) + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}(\tau),\tau)d\tau, \qquad \mathbf{x}(T) \sim p_{\text{prior}}. \tag{9.6.1}$$

时间步方法依据过去时刻离散更新以近似积分。本节转向以 ParaDiGMS 为代表的时间并行：建立于经典 Picard 迭代，以更多计算资源换取更快模拟。

9.6.2 ParaDiGMS 的方法

从轨迹到作为不动点更新的 Picard 迭代。 固定初态 $\mathbf{x}_T \sim p_{\text{prior}}$，将积分式视为完整候选轨迹到新轨迹的映射。给定 $\{\mathbf{y}(\tau)\}_{\tau\in[0,T]}$，定义

$$(\mathcal{L}[\mathbf{y}(\cdot)])(t) = \mathbf{x}_T + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{y}(\tau),\tau)d\tau, \quad t \in [0,T].$$

它固定初态，沿候选轨迹求速度来更新其他状态。满足 $\mathbf{x}^*(T) = \mathbf{x}_T$ 的经验 ODE 解恰为不动点 $\mathbf{x}^*(t) = \mathcal{L}[\mathbf{x}^*(\cdot)](t) = \mathbf{x}_T + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}^*(\tau),\tau)d\tau$。所以可寻找与积分方程一致的整条轨迹，而非严格逐步构造。

从满足初态的猜测（如常路径 $\mathbf{x}^{(0)}(t) \equiv \mathbf{x}_T$）出发，反复应用

$$\mathbf{x}^{(k+1)}(t) = \mathcal{L}[\mathbf{x}^{(k)}(\cdot)](t) = \mathbf{x}_T + \int_T^t \mathbf{v}_{\phi^\times}(\mathbf{x}^{(k)}(\tau),\tau)d\tau, \tag{9.6.2}$$

$k = 0,1,\ldots$。每次沿上一轨迹求速度，并同时更新全部时刻。

$T \to 0$ 网格上的离散 Picard。 选 M、$\Delta t = T/M$，递减均匀网格 $t_j = T - j\Delta t$，$j = 0,\ldots,M$，记 $\mathbf{x}_j^{(k)} := \mathbf{x}^{(k)}(t_j)$。逆时间使积分方向为负，左端点近似为

$$\int_T^{t_j} \mathbf{v}_{\phi^\times}(\mathbf{x}^{(k)}(\tau),\tau)d\tau \approx -\Delta t \sum_{i=0}^{j-1} \mathbf{v}_{\phi^\times}(\mathbf{x}_i^{(k)}, t_i).$$

于是

$$\mathbf{x}_j^{(k+1)} = \mathbf{x}_T - \Delta t \underbrace{\sum_{i=0}^{j-1} \mathbf{v}_{\phi\times}(\mathbf{x}_i^{(k)}, t_i)}_{\text{漂移累计和}}, \qquad j = 1, \ldots, M. \tag{9.6.3}$$

译注：源文将此称为分块区间 $[t_{i+1}, t_i]$ 的左端点近似，但实际取值 t_i 是递减序列的步首、在通常递增区间意义下为右端点。此处保留更新与负号；不混淆积分方向。

各漂移只依赖上一迭代的同一时间节点，可全网格独立并行。积分由累计和恢复，可以顺序求和，也可用并行前缀和（scan/滑动窗口）。

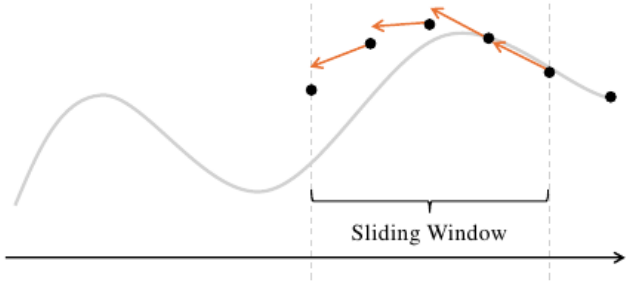


图 9.4: 在大小 $p = 4$ 的批窗口中，并行计算 $\mathbf{x}_{\ell:\ell+p}^{(k)}$ 的漂移。Sliding Window 为滑动窗口；轨迹、局部漂移箭头和轴按源图保留。来源：改编自 Shih et al. (2023)。

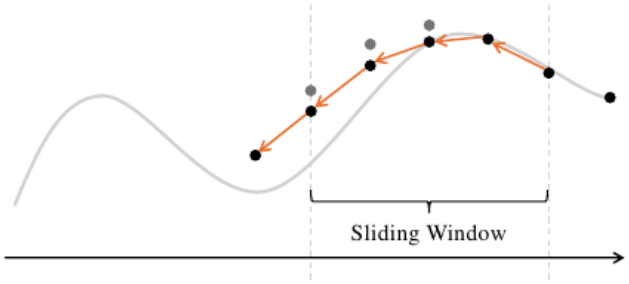


图 9.5: 用窗口内点的累计漂移，将值更新为 $\mathbf{x}_{\ell:\ell+p}^{(k+1)}$。来源：改编自 Shih et al. (2023)。

滑动窗口与并行求值。 为限制内存、利用并行硬件，在短的滑动索引块局部应用同一思想。固定窗口长度 p、左索引 ℓ，覆盖 $j = \ell, \ldots, \ell + p$，对应递减时间。在迭代 k 中：

1. **窗口内并行漂移求值**。只使用上一迭代，同时计算 $\mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i})$，$i = 0, \ldots, p-1$。这是从左边沿窗口推进所需的 p 个局部增量。

2. **左锚定累计更新**。以 $j = \ell$ 为锚点，累计子区间漂移：

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_\ell^{(k)} - \Delta t \sum_{i=0}^{j} \mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}), \qquad j = 0, \ldots, p-1. \tag{9.6.4}$$

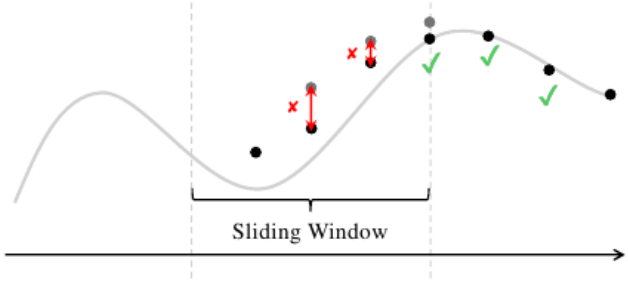


图 9.6: 基于误差 $\|\mathbf{x}_i^{(k+1)} - \mathbf{x}_i^{(k)}\|^2$ 决定窗口前移距离。红叉/绿勾按源示意保留。来源：改编自 Shih et al. (2023)。

这是离散 Picard 的局部窗口对应，以当前左边界为锚。负号反映递减时间，内和为前缀和，可高效并行计算全部部分和。

3. **进度控制与窗口前移**。用逐点 Picard 变化测量局部收敛：

$$\text{error}_j := \|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\|^2, \qquad j = 1, \dots, p-1,$$

与容差 $\text{tol}_{\ell+j}$ 比较。小表示连续两迭代局部一致，较大表示还需 Picard 平滑。步幅取第一个未通过位置，若均通过则取整个窗口长度：

$$\text{stride} := \min\big(\{j \geq 1 : \text{error}_j > \text{tol}_{\ell+j}\} \cup \{p\}\big), \qquad \ell \leftarrow \ell + \text{stride}.$$

原文将其解释为接受从左缘直到（不含）首个未收敛点之间的全部节点；全通过则接受整个窗口，最多前进 p，不跳过未通过节点。超出网格末端时，将窗口截为 $p \leftarrow \min\{p, M - \ell\}$。

前移暴露无初值的新节点时，原文说明复制窗口左边界值作常数外推，成本低且稳定，后续更新修正；也可用过去点线性或多项式外推。算法 8 总结流程。[9]

9.6.3 与时间步进求解器的关系

滑动窗口大小选择。 $p = 1$ 时无时间并行，退化为顺序基础更新；式 (9.6.4) 的离散下就是普通 Euler。更一般地，ParaDiGMS 规定跨时间如何并行，基础数值步可另选。将 Euler 替为 DDIM 或 DPM-Solver 可得 ParaDDIM、ParaDPMSolver。增大 p 暴露更多并行时刻，不改网格和总步数；Picard 反复修正状态，旨在逼近所选基础求解器的顺序离散轨迹；局部容差在算法中用作窗口推进或停止的判据。该判据本身不保证最终轨迹相对于顺序离散解的误差，也不构成无条件收敛保证；这些结论仍需额外条件。**译注：**源算法未显式写出未更新节点在迭代间的继承/复制，及最终各已接受节点的存储规则；此为原算法的记号/实现缺口，未擅加步骤。网格索引 0 的 $\mathbf{x}_0^{(0)}$ 对应时间 T，不应误作原数据样本 $\mathbf{x}(t = 0)$。

[9]译注：源文正文称新节点复制 “左边界”，但算法行 14 实际复制旧窗口右端 $\mathbf{x}_{\ell+J}^{(k+1)}$，此处分别照录，未静默统一。首失败点位置与将其作为新左锚的收敛叙述也需区分。算法只比较窗口内部 $j = 1, \dots, J-1$，本轮更新的末节点 $\ell + J$ 未列入容差测试；若内部点全通过，仍直接前移 J。所以已测节点的相邻迭代变化小，不自动控制末节点相对于顺序离散解的误差，更不证明达到连续精确解；最终误差保证还需要额外条件。这是对书中伪代码的限定，不是对原始 ParaDiGMS 实现的测试结论。

算法 8 含滑动窗口的 ParaDiGMS

Require: 漂移 $\mathbf{v}_{\phi^\times}$；网格 $\{t_j\}_{j=0}^{M}$；窗口长度 p；容差 $\{\mathrm{tol}_j\}_{j=1}^{M}$

Ensure: 近似轨迹 $\{\mathbf{x}_j^{(k)}\}_{j=0}^{M}$，$\mathbf{x}_M^{(k)}$ 对应 $t=0$

$k \leftarrow 0$，$\ell \leftarrow 0$

抽取 $\mathbf{x}_0^{(0)} \sim p_{\mathrm{prior}}$；对 $j=1,\dots,\min(p,M)$，令 $\mathbf{x}_j^{(0)} \leftarrow \mathbf{x}_0^{(0)}$ ▷ 常数外推

while $\ell < M$ **do**

  $J \leftarrow \min(p, M-\ell)$ ▷ 当前窗口长度

  步骤 1：并行

  对 $i=0,\dots,J-1$：$\mathbf{g}_i \leftarrow \mathbf{v}_{\phi^\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i})$ ▷ 冻结上次迭代

  对 $j=0,\dots,J-1$：计算前缀和 $\mathbf{S}_j \leftarrow \sum_{i=0}^{j} \mathbf{g}_i$

  步骤 2：累计更新

  对 $j=0,\dots,J-1$：$\mathbf{x}_{\ell+j+1}^{(k+1)} \leftarrow \mathbf{x}_{\ell}^{(k)} - \Delta t \mathbf{S}_j$

  步骤 3：进度控制与窗口前移

  对 $j=1,\dots,J-1$：$\mathrm{error}_j \leftarrow \|\mathbf{x}_{\ell+j}^{(k+1)} - \mathbf{x}_{\ell+j}^{(k)}\|^2$

  $\mathrm{stride} \leftarrow \min(\{j \in \{1,\dots,J-1\} : \mathrm{error}_j > \mathrm{tol}_{\ell+j}\} \cup \{J\})$

  初始化新节点

  对 $r=1,\dots,\min\{\mathrm{stride}, M-\ell-J\}$：$\mathbf{x}_{\ell+J+r}^{(k+1)} \leftarrow \mathbf{x}_{\ell+J}^{(k+1)}$

  $\ell \leftarrow \ell + \mathrm{stride}$；$k \leftarrow k+1$

end while

return $\{\mathbf{x}_j^{(k)}\}_{j=0}^{M}$

与高阶求解器的兼容性。 Picard 框架规定时间并行，局部积分规则另选。例如用梯形替代步首规则：

$$\mathbf{x}_{\ell+j+1}^{(k+1)} = \mathbf{x}_{\ell}^{(k)} - \Delta t\Big[\tfrac{1}{2}\mathbf{v}_{\phi\times}(\mathbf{x}_{\ell}^{(k)}, t_{\ell}) + \sum_{i=1}^{j} \mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+i}^{(k)}, t_{\ell+i}) + \tfrac{1}{2}\mathbf{v}_{\phi\times}(\mathbf{x}_{\ell+j+1}^{(k)}, t_{\ell+j+1})\Big], \quad j = 0, \ldots, p-1.$$

$j = 0$ 即两端漂移的一步梯形，j 更大则累计整个窗口的梯形贡献。所有漂移都取上一迭代，仍可并行，内部贡献用前缀和。

更一般地，可用已有 DDIM 或 DPM-Solver 为基础，Picard 更新由相应基础增量构成，而非上面梯形式。精确形式依求解器而定，因为高阶法可能用中间阶段或历史求值。对给定顺序基础求解器构造的 ParaDiGMS，精确不动点收敛恢复相应顺序离散轨迹；有限停止容差下，除基础离散误差外还有剩余不动点迭代误差。

9.7 结束语

本章面对扩散模型缓慢迭代采样这一主要实践局限，探索以更好经验 PF-ODE 数值求解器加速的免训练方法：

1. DDIM 是一阶因子化指数积分，解析保留调度、冻结网络预测；
2. DEIS 以过去模型求值外推预测变化，扩展为高阶多步更新；
3. DPM-Solver 引入对数 SNR 坐标，用步内求值构造高阶更新；DPM-Solver++ 进一步在数据形式中发展单步和多步变体。

共同原则是利用解析已知的扩散结构，将数值近似集中于学习预测。差异在预测/时间参数化，以及高阶信息来自步内阶段还是历史。ParaDiGMS 则通过不动点迭代和并行求值重组跨时间计算，形成互补方向。许多实际场景中，这些方法把数百或数千次求值降至几十次。

但免训练方法仍根本依赖迭代：即使部分并行，也在数值近似连续生成轨迹。能否只用一步或极少步获得高质量生成？最后的 D 部通过训练式加速探讨：第 10 章研究慢预训练教师向快学生的蒸馏，第 11 章研究从头直接学习由 ODE 流定义的少步生成器。从改进求解器转向学习生成解映射的快速近似，旨在结合扩散质量与一步/少步速度。

D 部：走向快速扩散生成器的学习

第十章　用于快速采样的蒸馏方法

本章介绍训练式扩散加速，让新生成器只用一步或少数几步采样。核心是蒸馏：让快学生学习慢的预训练扩散教师采样器。教师可能需数百步，学生少步即可达到相近质量。[1]数值求解器改进积分方案，蒸馏则直接训练生成器走高效捷径。两种主要范式是分布层面蒸馏，跳过完整轨迹模拟、对齐学生和教师输出分布；以及流映射层面蒸馏，以更快、更紧凑方式复现教师采样路径。

学完本章后，你将能够：

- 区分两种主要蒸馏目标：教师分布与状态间流映射；
- 理解以得分监督匹配教师含噪边缘的分布蒸馏；
- 理解学习教师生成转移的流映射蒸馏，以及渐进蒸馏如何逐步以学生一步替代教师两步。

阅读路线。　假定已有预训练扩散教师，关键区别是学生学分布还是流映射。下一章再问，没有教师时如何学习快速映射。

10.1　序幕

慢采样是扩散模型核心瓶颈。Tweedie 公式（第 6.3.1 节）使模型可解释为 $\mathbf{x}$ 预测器：

$$\mathbf{x}_{\phi\times}(\mathbf{x}_t, t) \approx \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t].$$

条件期望考虑含噪输入所对应的所有可能干净数据。自然想一步用此预测生成，但平均许多可能结果会过度平滑，少数去噪步常得到模糊低质样本。

另一方面，扩散沿 ODE 或 SDE 以长序列迭代采样，质量高而网络求值昂贵。确定性 n 阶 ODE 法在标准正则假设下，局部误差 $O(h^{n+1})$、固定区间全局离散误差 $O(h^n)$，$h = \max_i |t_i - t_{i-1}|$。同一学习场上，粗网格一般增加数值误差，但样本保真度不必随步数单调变化，形成精度与成本权衡。

蒸馏假定有良好教师，训练学生用单次前馈或少步复现其行为，把多步压缩为快过程，绕过慢迭代、保持高保真。下面介绍分布与流映射两视角。[2]

[1]此处蒸馏指减少采样步数，而非缩小模型尺寸。

[2]按历史次序，流映射蒸馏更早：知识蒸馏 KD（Luhman and Luhman, 2021）出现在 2021，渐进蒸馏 PD（Salimans and Ho, 2021）出现在 2022，早于约 2023 兴起的分布蒸馏族。为叙述顺畅并连接下一章，此处先讲分布层面。原年份和文内引文年份按源保留。

10.1.1 分布层面蒸馏

训练一步生成器 $G_\theta(\mathbf{z})$，将 $\mathbf{z}\sim p_{\text{prior}}$ 映为 $\widehat{\mathbf{x}}=G_\theta(\mathbf{z})$，诱导分布 p_θ 近似数据。通常最小化合适统计散度，如 $\min_\theta D(p_\theta(\widehat{\mathbf{x}}),p_{\text{data}}(\widehat{\mathbf{x}}))$，$D$ 可为 KL。

实践中，对齐预训练模型输出的经验分布 $p_{\phi^\times}$，将其作为数据替代目标：

$$\min_\theta D(p_\theta(\widehat{\mathbf{x}}),p_{\phi^\times}(\widehat{\mathbf{x}})).$$

不显式计算散度，而以预训练教师和当前学生分布的估计量构造可计算梯度。KL 匹配时梯度为学生与目标得分之差。分布对齐把多步过程蒸馏为一步，详见第 10.2 节。

10.1.2 流映射层面蒸馏

PF-ODE 可用任意预测参数化表达：

$$\frac{d\mathbf{x}(\tau)}{d\tau}=f(\tau)\mathbf{x}(\tau)-\tfrac{1}{2}g^2(\tau)\nabla_{\mathbf{x}}\log p_\tau(\mathbf{x}(\tau))=:\mathbf{v}^*(\mathbf{x}(\tau),\tau). \tag{10.1.1}$$

从 s 的状态出发逆演化到 $t\le s$ 的流映射为

$$\Psi_{s\to t}(\mathbf{x}_s):=\mathbf{x}_s+\int_s^t \mathbf{v}^*(\mathbf{x}(\tau),\tau)d\tau. \tag{10.1.2}$$

它把噪声状态输运到较低噪声，最终到 $t=0$ 数据。采样即对 $\mathbf{x}_T\sim p_{\text{prior}}$ 计算 $\Psi_{T\to 0}$。迭代求解常仍需较多步（如 DPM-Solver 至少约 10–20 次 NFE，沿用源举例），慢于 GAN 等一步模型。

问题 10.1.1. 能否直接学习解映射 $\Psi_{s\to t}(\mathbf{x}_s)$？

尤其学到 $T\to 0$ 映射就能一步生成。

轨迹蒸馏。 训练网络在实例层面近似解映射。积分一般无闭式，训练时需数值近似，定义通用记号

$$\text{Solver}_{s\to t}(\mathbf{x}_s;\phi^\times),\qquad \text{或简写}\,\text{Solver}_{s\to t}(\mathbf{x}_s), \tag{10.1.3}$$

表示从 $\mathbf{x}_s$ 开始，以教师参数数值积分经验 PF-ODE。

早期方法：直接知识蒸馏。 训练 $G_\theta(\mathbf{x}_T,T,0)\approx\text{Solver}_{T\to 0}(\mathbf{x}_T)$，用完整轨迹解监督一步/少步。这是早期 KD（Luhman and Luhman, 2021）的思想，损失为

$$\mathcal{L}_{\text{KD}}(\theta):=\mathbb{E}_{\mathbf{x}_T\sim p_{\text{prior}}}\|G_\theta(\mathbf{x}_T,T,0)-\text{Solver}_{T\to 0}(\mathbf{x}_T)\|_2^2.$$

它提供直接教师监督，却不能利用原训练数据的强监督；若训练循环内解 ODE，每次参数更新须生成目标，成本很高；只学 $T\to 0$ 全局映射还可能丢失中间状态控制性，第 八章多数可控生成技巧不能直接使用。

渐进蒸馏预告。 PD（Salimans and Ho, 2021）用教师局部片段训练时间条件学生。固定 $t_0 = T > \cdots > t_N = 0$，教师给出相邻步映射。学生匹配两步组合：

$$\text{Student}_{t_k \to t_{k+2}} \approx \text{Teacher}_{t_{k+1} \to t_{k+2}} \circ \text{Teacher}_{t_k \to t_{k+1}}, \qquad k = 0, 2, 4, \ldots,$$

用简单回归如 MSE。训练后学生在 $t_0 \to t_2 \to \cdots \to t_N$ 上推进，以 $N/2$ 次转移走完同一跨度。训练好的学生成为新教师，在时间步加倍的粗网格重复，$N \to N/2 \to N/4 \to \cdots$，直到目标步数；保持全局时间跨度、不断压缩时间分辨率。

流映射学习的统一视角。 KD、PD 等可写为

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t}\mathbb{E}_{\mathbf{x}_s \sim p_s}\left[w(s,t)d\big(G_\theta(\mathbf{x}_s, s, t), \Psi_{s\to t}(\mathbf{x}_s)\big)\right], \tag{10.1.4}$$

$w \geq 0$ 权衡时间对，d 可为平方 L^2 或 L^1，p_s 是正向含噪边缘。理想流无闭式，通常依教师或其他可计算替代。

KD 只用 $(s,t) = (T, 0)$，等价于退化权重 $w = \delta(s-T)\delta(t)$。若 $p_T = p_{\text{prior}}$，[3]则

$$\mathbb{E}_{\mathbf{x}_T \sim p_T}\|G_\theta(\mathbf{x}_T, T, 0) - \Psi_{T\to 0}(\mathbf{x}_T)\|_2^2 \approx \mathcal{L}_{\text{KD}},$$

实际用数值解替代理想目标。另一视角见原附录 D.5。PD 则用许多邻近时间对，强制两短步等于直接跨两步，见式 (10.3.3)。

直接理想监督通常不可行，已有多种高效目标近似，但成功常取决于教师质量。第 11 章返回统一式，给出去掉教师、从头训练的原则框架。

10.2 基于分布的蒸馏

多项工作同时以不同名称推进此方向，包括 DMD（Yin et al., 2024b; Yin et al., 2024a）、VSD（Poole et al., 2023; Wang et al., 2023; Luo et al., 2023; Lu and Song, 2024）和 SiD（Zhou et al., 2024）。技术不同但原则相同：使生成器的正向加噪边缘匹配教师。以 VSD 为代表，其他方法遵循相近原则。[4]

10.2.1 以 VSD 为代表的表述

正向过程。 以 $p_0 = p_{\text{data}}$ 为初态，$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}$ 诱导边缘 p_t，$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。另一方面，$p_0^\theta$ 是确定性一步生成器从 $\mathbf{z} \sim p_{\text{prior}}$ 产生的分布。对它使用同一核，定义

$$\mathbf{x}_t^\theta := \alpha_t G_\theta(\mathbf{z}) + \sigma_t \boldsymbol{\epsilon}, \tag{10.2.1}$$

诱导 p_t^θ。两族共享高斯核，仅初始分布不同。

[3]只有调度在 T 精确到达先验时此等式成立；通常足够大 T 下仅有 $p_T \approx p_{\text{prior}}$。

[4]历史上 VSD（Wang et al., 2023）为文本到 3D 生成提出，预训练 2D 扩散经可微渲染器提供分布监督。其单粒子（Dirac）特例，在相应时间权重和参数化约定下恢复基本 SDS（Poole et al., 2023）更新。

训练目标与梯度。 文献通常最小化

$$\begin{aligned}\mathcal{L}_{\mathrm{VSD}}(\theta) &:= \mathbb{E}_t[\omega(t) D_{\mathrm{KL}}(p_t^\theta \| p_t)] \\ &= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\left[\omega(t)\big(\log p_t^\theta(\mathbf{x}_t^\theta) - \log p_t(\mathbf{x}_t^\theta)\big)\right],\end{aligned}$$

$\omega(t) \geq 0$。KL 特殊性见第 10.2.3 节。Wang et al. (2023) 指出总体全局最优在 $p_0^{\theta^*} = p_{\mathrm{data}}$ 达到，故该目标是有原则的分布匹配损失。但密度形式缺乏高效机制，取参数梯度可得到可用表达。简记 $\widehat{\mathbf{x}}_t := \mathbf{x}_t^\theta$。

命题 10.2.1 ($\mathcal{L}_{\mathrm{VSD}}$ 的参数梯度)**.** 有

$$\nabla_\theta \mathcal{L}_{\mathrm{VSD}}(\theta) = \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\left[\omega(t)\alpha_t\big(\nabla_{\mathbf{x}} \log p_t^\theta(\widehat{\mathbf{x}}_t) - \nabla_{\mathbf{x}} \log p_t(\widehat{\mathbf{x}}_t)\big)^\top \partial_\theta G_\theta(\mathbf{z})\right]. \tag{10.2.2}$$

证明. 链式法则给出

$$\begin{aligned}\nabla_\theta \mathcal{L}_{\mathrm{VSD}} &= \nabla_\theta \mathbb{E}_t[\omega(t) D_{\mathrm{KL}}(p_t^\theta \| p_t)] \\ &= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\left[\omega(t)\partial_\theta\big(\log p_t^\theta(\widehat{\mathbf{x}}_t) - \log p_t(\widehat{\mathbf{x}}_t)\big)\right] \\ &= \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\Big[\omega(t)\Big(\underbrace{\partial_\theta \log p_t^\theta(\widehat{\mathbf{x}}_t)}_{\text{第一项：固定输入的显式参数导数}} \\ &\qquad + (\nabla_{\mathbf{x}} \log p_t^\theta(\widehat{\mathbf{x}}_t))^\top \partial_\theta \widehat{\mathbf{x}}_t - (\nabla_{\mathbf{x}} \log p_t(\widehat{\mathbf{x}}_t))^\top \partial_\theta \widehat{\mathbf{x}}_t\Big)\Big].\end{aligned}$$

第一项由得分恒等式消去：

$$\mathbb{E}_{\widehat{\mathbf{x}}_t \sim p_t^\theta}[\partial_\theta \log p_t^\theta(\widehat{\mathbf{x}}_t)] = \int \partial_\theta p_t^\theta(\mathbf{x}) d\mathbf{x} = \partial_\theta \int p_t^\theta(\mathbf{x}) d\mathbf{x} = 0.$$

重参数化给出 $\partial_\theta \widehat{\mathbf{x}}_t = \alpha_t \partial_\theta G_\theta(\mathbf{z})$，代回即得式 (10.2.2)，细节见原附录 D.5。 □

译注： 源推导依赖归一化、可微性、积分/求导交换及有限期望等正则条件；总体最优陈述还以非退化加噪和有效时间权重等为前提。不将它提升为任意退化权重、有限网络或交替训练必达全局匹配的保证。

取参数梯度自然产生得分。因此需近似学生得分与数据得分，下节说明。

10.2.2 VSD 的训练流程

现有工作（Yin et al., 2024b; Yin et al., 2024a; Poole et al., 2023; Wang et al., 2023; Luo et al., 2023; Lu and Song, 2024）通常采用双层优化：在生成样本上训练新扩散模型近似学生得分；以预训练模型在合成样本上近似理想目标得分。交替两阶段：

- **得分估计阶段**。固定 θ，取 $\widehat{\mathbf{x}}_0 = G_\theta(\mathbf{z})$、$\widehat{\mathbf{x}}_t = \alpha_t \widehat{\mathbf{x}}_0 + \sigma_t \boldsymbol{\epsilon}$，用已知核训练 DSM：

  $$\mathcal{L}_{\mathrm{DSM}}(\zeta; \theta) = \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}} \|\mathbf{s}_\zeta(\widehat{\mathbf{x}}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\widehat{\mathbf{x}}_t \mid \widehat{\mathbf{x}}_0)\|^2.$$

  固定生成器时，最优得分近似 $\nabla_{\mathbf{x}} \log p_t^\theta$。

- **生成器更新阶段**。冻结 $\mathbf{s}_\zeta$（停止梯度），以两得分代理更新

  $$\begin{aligned}&\mathbf{s}_\zeta(\widehat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}} \log p_t^\theta(\widehat{\mathbf{x}}_t), \qquad \mathbf{s}_{\phi^\times}(\widehat{\mathbf{x}}_t, t) \approx \nabla_{\mathbf{x}} \log p_t(\widehat{\mathbf{x}}_t), \\ &\nabla_\theta \mathcal{L}_{\mathrm{VSD}} \approx \mathbb{E}_{t,\mathbf{z},\boldsymbol{\epsilon}}\left[\omega(t)\alpha_t(\mathbf{s}_\zeta(\widehat{\mathbf{x}}_t, t) - \mathbf{s}_{\phi^\times}(\widehat{\mathbf{x}}_t, t))^\top \partial_\theta G_\theta(\mathbf{z})\right].\end{aligned}$$

交替训练时，理想辅助模型跟踪当前学生得分，教师近似目标得分。总体层面，若两得分在某个 $\sigma_t > 0$、$\alpha_t \neq 0$ 的噪声水平一致，则相应归一化密度一致；非零信号下高斯加噪具有单射性，进一步推出 $p_0^\theta = p_{\text{data}}$。实际均为有限学习网络，这刻画理想总体解，不保证交替优化能达成等式。

10.2.3 KL 之外：一般散度及 KL 的特殊性

分布匹配不必用 KL，原则上可用一般 f 散度（原式 (1.1.4)）：

$$D_f(p_t^\theta \| p_t) = \int p_t(\mathbf{x}) f\left(\frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})}\right) d\mathbf{x}, \qquad r_t(\mathbf{x}) := \frac{p_t^\theta(\mathbf{x})}{p_t(\mathbf{x})}.$$

反向 KL 便利在于梯度结构。f 二次可微凸、密度为正时，路径梯度为

$$\nabla_\theta D_f(p_t^\theta \| p_t) = \mathbb{E}_{\widehat{\mathbf{x}}_t \sim p_t^\theta}\left[r_t(\widehat{\mathbf{x}}_t) f''(r_t(\widehat{\mathbf{x}}_t)) \big(\nabla_{\mathbf{x}} \log p_t^\theta(\widehat{\mathbf{x}}_t) - \nabla_{\mathbf{x}} \log p_t(\widehat{\mathbf{x}}_t)\big)^\top \partial_\theta \widehat{\mathbf{x}}_t \right].$$

概念上有三部分：密度比权重 $r_t f''(r_t)$ 决定何处、以多强更新；得分失配决定方向；参数敏感度 $\partial_\theta \widehat{\mathbf{x}}_t$ 把样本空间信号拉回参数。各散度共享得分差 $\nabla \log p_t^\theta - \nabla \log p_t = \nabla \log r_t$，区别是不同密度比区域的权重。通常严格凸的选择下，总体匹配条件仍是两密度相同。

VSD 的反向 KL 取 $f(r) = r \log r$，故 $r f''(r) = 1$，密度比权重消失，恢复式 (10.2.2)。得分已知后无需额外逐点密度比估计。一般 f 散度则需 $r_t f''(r_t)$；得分差虽给出对数比梯度，隐式生成器的比值本身一般不可直接得，需要额外估计。例如正向 KL 取 $f(r) = -\log r$，$r f''(r) = 1/r$，更强调模型密度相对目标小的区域。

这一视角直接联系原附录 B.3 的 Wasserstein 梯度流：分布层面，反向 KL 梯度流以目标得分减模型得分移动粒子；VSD 参数梯度含同样失配，经生成器 Jacobian 拉回。前者描述理想分布空间运动，源文将 VSD 描述为通过有限维共享生成器更新来实现这一运动。[5]

10.3 渐进蒸馏

PD（Salimans and Ho, 2021）包含两个过程，逐渐减少高质采样所需步数，同时保持教师轨迹保真度：

- **蒸馏操作：**把预训练教师（初始为扩散模型）的确定性采样器（如 DDIM），蒸馏成只用半数步复现相同轨迹的学生；
- **渐进操作：**重复上述过程，每轮减半，直至在小固定预算内（通常 1–4 步）生成高质样本。

先讲蒸馏操作，再给完整训练，最后推广到 CFG。

[5]译注：这里体现相同得分差信号经生成器 Jacobian 拉回的联系，不能据此把有限参数梯度流等同于无约束 Wasserstein 粒子流。固定时刻记 $X_\theta(z)$ 的 Jacobian 为 $J_\theta(z) = \partial_\theta X_\theta(z)$，记固定时刻的模型密度 $q_\theta = p_t^\theta$、目标密度 $p = p_t$，并定义 $a(x) = \nabla_x \log q_\theta(x) - \nabla_x \log p(x)$。这里仅比较该时刻的反向 KL 信号，省略或吸收正权重，不代替完整的跨时间 VSD 更新。对该时刻的反向 KL 作普通参数梯度下降时，诱导的粒子速度为 $-J_\theta(z)\mathbb{E}_{z'}[J_\theta(z')^\top a(X_\theta(z'))]$，一般不等于 $-a(X_\theta(z))$。共享参数因而诱导依赖参数化的样本耦合或受限投影；相同分布的不同参数化也可能给出不同运动速度。只有额外条件成立时才可认定二者一致，有限网络或实际训练不由此保证达到总体最优。

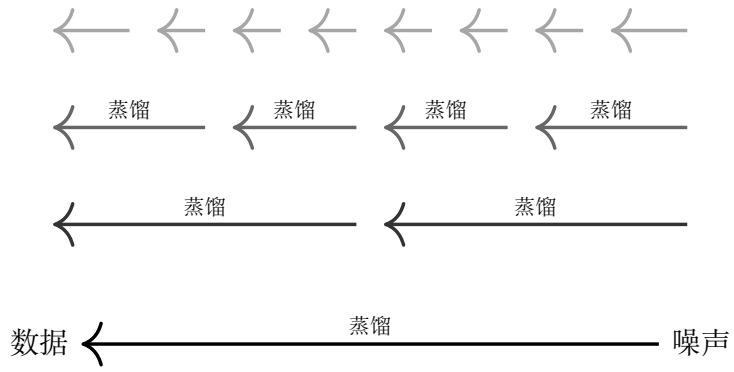


图 10.1: 渐进蒸馏示意。每轮训练学生一步复现相邻教师两步，将 N 步蒸馏为 $N/2$ 步；重复减半至目标步数。箭头表示噪声到数据方向上，多步教师转移压缩为较少学生步。Data、Noise、Distill 分别为数据、噪声、蒸馏。来源：原作者；位置及 15 条向左箭头用可编辑 tikzcd 重建。

10.3.1 PD 中的蒸馏操作

固定数据预测 DDIM 为时间步规则，仍以 $\mathrm{Solver}_{s\to t}$ 表示把当前教师去噪器代入 DDIM 的确定性映射。首轮教师是预训练扩散，此映射对应 DDIM 近似原 PF-ODE；之后教师为前轮学生，只表示当前教师诱导的 DDIM 转移，不是原扩散 PF-ODE。

从含噪输入 $\mathbf{x}_s = \alpha_s \mathbf{x}_0 + \sigma_s \boldsymbol{\epsilon}$ 出发，训练学生预测伪干净目标 $\widetilde{\mathbf{x}}$，使学生一步 $s \to t$ 复现教师两步 $s \to u \to t$。教师本轮数据预测记作 $\mathbf{x}_{\phi^\times}(\mathbf{x}, \tau)$，计算

$$\widetilde{\mathbf{x}}_u := \mathrm{Solver}_{s\to u}(\mathbf{x}_s; \mathbf{x}_{\phi^\times}), \qquad \widetilde{\mathbf{x}}_t := \mathrm{Solver}_{u\to t}(\widetilde{\mathbf{x}}_u; \mathbf{x}_{\phi^\times}).$$

问题 10.3.1. 时刻 s 的哪个伪干净值 $\widetilde{\mathbf{x}}$，使直接一步与两步获得相同终点？即求解

$$\widetilde{\mathbf{x}}_t = \mathrm{Solver}_{s\to t}(\mathbf{x}_s; \widetilde{\mathbf{x}}).$$

得到闭式目标后，以数据预测学生 $\mathbf{f}_\theta(\mathbf{x}_s, s)$ 最小化

$$\min_\theta \ \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(\lambda_s) \| \mathbf{f}_\theta(\mathbf{x}_s, s) - \widetilde{\mathbf{x}} \|_2^2 \right]. \tag{10.3.1}$$

DDIM 以初等代数给出目标，离散和连续时间均适用。

引理 10.3.1 (DDIM 的二步合一目标)**.** 起点为 $\mathbf{x}_s$、求解规则为 *DDIM* 时，

$$\widetilde{\mathbf{x}} = \frac{\sigma_s}{\alpha_t \sigma_s - \alpha_s \sigma_t} \widetilde{\mathbf{x}}_t - \frac{\sigma_t}{\alpha_t \sigma_s - \alpha_s \sigma_t} \mathbf{x}_s,$$

其中用式 (9.2.2) 两次得到

$$\widetilde{\mathbf{x}}_u = \frac{\sigma_u}{\sigma_s} \mathbf{x}_s + \alpha_s \left(\frac{\alpha_u}{\alpha_s} - \frac{\sigma_u}{\sigma_s} \right) \mathbf{x}_{\phi^\times}(\mathbf{x}_s, s),$$
$$\widetilde{\mathbf{x}}_t = \frac{\sigma_t}{\sigma_u} \widetilde{\mathbf{x}}_u + \alpha_u \left(\frac{\alpha_t}{\alpha_u} - \frac{\sigma_t}{\sigma_u} \right) \mathbf{x}_{\phi^\times}(\widetilde{\mathbf{x}}_u, u).$$

证明. 单步终点 $\widetilde{\mathbf{x}}'_t = \frac{\sigma_t}{\sigma_s}\mathbf{x}_s + \alpha_s(\alpha_t/\alpha_s - \sigma_t/\sigma_s)\widetilde{\mathbf{x}}$。要求它等于两步终点，解得

$$\begin{aligned}\widetilde{\mathbf{x}}_t = \widetilde{\mathbf{x}}'_t &\iff \widetilde{\mathbf{x}}_t = \frac{\sigma_t}{\sigma_s}\mathbf{x}_s + \alpha_s\left(\frac{\alpha_t}{\alpha_s} - \frac{\sigma_t}{\sigma_s}\right)\widetilde{\mathbf{x}} \\ &\iff \widetilde{\mathbf{x}} = \frac{\widetilde{\mathbf{x}}_t - (\sigma_t/\sigma_s)\mathbf{x}_s}{\alpha_s(\alpha_t/\alpha_s - \sigma_t/\sigma_s)} \\ &\iff \widetilde{\mathbf{x}} = \frac{\sigma_s\widetilde{\mathbf{x}}_t - \sigma_t\mathbf{x}_s}{\alpha_t\sigma_s - \alpha_s\sigma_t}. \end{aligned} \tag{10.3.2}$$

□

译注： 闭式反解要求分母非零，并按所用 DDIM 参数化保证涉及的调度比值有定义；源文未在引理标题处重复这些条件。不把同信噪比退化时间对包含为可逆情形。

此式计算一步精确落到教师两步输出的伪目标。

实际离散网格和损失。 固定递减网格，简记 $s = t_k, u = t_{k+1}, t = t_{k+2}$，学生匹配教师两相邻映射组合。标准减半设 N 偶数，$k \sim \mathcal{U}\{0, 2, \dots, N-2\}$，目标变为

$$\min_\theta \ \mathbb{E}_k \mathbb{E}_{\mathbf{x}_{t_k}\sim p_{t_k}}\left[w(\lambda_{t_k})\|\mathbf{f}_\theta(\mathbf{x}_{t_k}, t_k) - \widetilde{\mathbf{x}}^{(k)}\|_2^2\right].$$

均匀网格时 $t_k = T(1 - k/N)$，相邻三时刻为 $s = T(1-k/N)$、$u = T(1-(k+1)/N)$、$t = T(1-(k+2)/N)$，步长 $\Delta s = T/N$。

10.3.2 PD 完整训练流程及采样

局部配对训练后，学生跨原网格每隔一个节点，以 $N/2$ 次转移走同一 $[0, T]$。学生成为新教师，在更粗网格重复，步长加倍，每轮新学生从更新教师初始化，直到所需推断步数。

采样。 推断用当前学生作 DDIM 去噪器，沿训练诱导粗网格推进。首轮跳 2 ($t_0 \to t_2 \to \cdots$)，下轮跳 4，再继续每轮减半步数，起止时间不变。

10.3.3 补充讨论：局部半群匹配及推广求解器的可能

PD 作为局部半群匹配。 在统一目标 (10.1.4) 中，用教师诱导替代近似不可得理想映射，利用 ODE 半群性质 $\Psi_{s\to t} = \Psi_{u\to t} \circ \Psi_{s\to u}$（原式 (11.2.1) 进一步讨论）。PD 局部训练学生一步匹配教师相邻两片段：

$$\mathbb{E}_s \mathbb{E}_{\mathbf{x}_s\sim p_s}\Big\|\underbrace{G_\theta(\mathbf{x}_s, s, s-2\Delta s)}_{\text{学生一步}} - \underbrace{\mathrm{Solver}_{s-\Delta s\to s-2\Delta s}(\mathrm{Solver}_{s\to s-\Delta s}(\mathbf{x}_s))}_{\text{教师两步组合}}\Big\|_2^2. \tag{10.3.3}$$

教师足够准确时，组合近似短递减网格上的半群关系

$$\Psi_{s\to s-2\Delta s} = \Psi_{s-\Delta s\to s-2\Delta s} \circ \Psi_{s\to s-\Delta s} \approx \mathrm{Solver}_{s-\Delta s\to s-2\Delta s} \circ \mathrm{Solver}_{s\to s-\Delta s}.$$

训练只需短片段，不必从 s 完整滚动至 0。将学生少步映射定义为学习跳跃的复合：

$$G_\theta(\mathbf{x}_s, s, 0) = \big(G_\theta(\cdot, 2\Delta s, 0) \circ \cdots \circ G_\theta(\cdot, s, s-2\Delta s)\big)(\mathbf{x}_s).$$

概念上，局部损失是全局回归 $\mathbb{E}_{s,\mathbf{x}_s}\|G_\theta(\mathbf{x}_s, s, 0) - (\mathrm{Solver})^{\circ}_{s\to 0}(\mathbf{x}_s)\|_2^2$ 的高效替代，其中上标圆圈表示步长 Δs 网格上的完整教师复合，近似理想全局映射。

可以用其他求解器吗？ 原则更一般：多个教师细步产生端点，训练学生粗步到达同一端点。粗更新对学生网络预测可逆时可得伪目标；DDIM 对单个数据预测仿射，故解析可逆。其他可类似反解的规则也适用。

复杂多阶段法用多个网络求值、多步法依历史、隐式法需求耦合方程，单输出反解未必存在。此时可直接计算学生粗步端点，与教师细步端点匹配，适当时对学生求解器反传。粗步可能多次求值，所以减少时间步不必同比减少 NFE。随机采样器固定或耦合教师/学生随机数后也可作路径匹配；若无此耦合，端点未必相同，通常应以分布而非路径匹配为目标。

10.3.4 含引导的 PD

Meng et al. (2023) 给出两阶段 CFG 蒸馏：先把引导蒸馏到接收权重输入的单网络，再用 PD 减少步数，在像素与潜空间（如 Stable Diffusion）均演示。

第一阶段：蒸馏引导。 预训练条件数据预测记为 $\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, c)$，$c = \varnothing$ 表示无条件。加权 CFG 写为

$$\mathbf{x}^{\omega}_{\phi^\times}(\mathbf{x}_s, s, c) := (1+\omega)\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, c) - \omega\mathbf{x}_{\phi^\times}(\mathbf{x}_s, s, \varnothing), \tag{10.3.4}$$

$\omega \sim p_\omega$，通常为 $\mathcal{U}[\omega_{\min}, \omega_{\max}]$。[6]

新模型 $\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, c, \omega)$ 直接接收权重，以监督回归拟合该组合：

$$\min_{\theta_1} \mathbb{E}_{\omega\sim p_\omega, s, \mathbf{x}\sim p_{\text{data}}, \mathbf{x}_s\sim p(\mathbf{x}_s|\mathbf{x})} \left[\lambda(s)\|\mathbf{x}_{\theta_1}(\mathbf{x}_s, s, c, \omega) - \mathbf{x}^{\omega}_{\phi^\times}(\mathbf{x}_s, s, c)\|_2^2\right].$$

$\lambda(s)$ 为标准调度权重，每次抽取 ω，使一个网络模拟不同强度 CFG。

第二阶段：PD。 第一阶段模型作教师，按第 10.3.2 节，渐进蒸馏为条件学生 $\mathbf{x}_{\theta_2}(\mathbf{x}_s, s, c, \omega)$，每轮步数减半。

10.4 结束语

本章介绍第一大类训练式加速，从数值求解改为让快学生复现慢教师。分布蒸馏以 VSD 等为代表，跨噪声水平对齐相应得分，使学生输出分布匹配教师，提供稳定的非对抗目标；流映射蒸馏直接近似教师解轨迹，PD 每轮减半，把长迭代压至少步。

这些方法连接迭代扩散的样本质量与一步生成器速度，为高效高保真合成提供路径。但教师依赖带来两阶段流程：先训练强大慢教师，再蒸馏。能否完全绕过教师，以独立原则直接从数据学习快速生成器？下一章探讨：

1. 一致性模型等开创方法，学习从 ODE 轨迹任意点到终点的映射；

2. 推广一致性模型，学习一步从轨迹任意点映射到另一点。

从改进求解器或蒸馏解，转向学习解映射自身，推动兼具有原则性和高效率设计的新生成模型。

[6]译注：源文称其为式 (8.3.3) 的组合，却在此用 $(1+\omega, -\omega)$，而第 8 章采用 $(\omega, 1-\omega)$。这是权重平移约定：本式 $\omega = 0$ 对应纯条件，等价于第 8 章权重 1。照录本章定义，不能把两处同名 ω 的数值直接等同。

第十一章　从头学习快速生成器

真理总是在简单之中，而不在事物的繁多与混乱之中。　　*Isaac Newton*

第 十章通过蒸馏把慢迭代采样压为少步。工程上，两阶段实用，因为它把复杂生成训练拆为独立清楚目标：第一阶段学习分布，第二阶段加速或改善质量。分开优化使系统更易管理、更稳定可靠。

本章转向推动深度生成建模的核心问题：

问题 11.0.1. 能否设计独立生成原则，使训练稳定高效、采样快速，而且用户容易引导或控制输出？

我们讨论无需预训练模型、直接训练少步扩散生成器。核心对象是流映射模型。流映射是经典 ODE 解映射，根植于微分方程和动力系统，在连续介质与流体力学中密切联系追踪物质粒子运动：$\Psi_{s\to t}$ 把时刻 s 的状态映射为指定动力学下时刻 t 的状态。模型直接近似该映射，以一至数次网络求值跨越长轨迹。[1]这一表述为把概率质量从先验输运到数据、同时保持各中间时刻正向扩散规定的边缘提供原则性途径。

学完本章后，你将能够：

- 区分瞬时速度场与 ODE 解映射（流映射）；
- 理解精确 ODE 流的半群性质，及其如何启发一致性学习目标；
- 理解一致性模型、一致性轨迹模型与 Mean Flow 如何学习特殊或一般流映射；
- 区分理想映射恒等式与实践近似，理解适当参数化如何兼顾少步生成与局部速度信息。

阅读路线。　各方法是学习同一 ODE 流映射的不同参数化和训练策略。

11.1　序幕

流映射模型的动机。　第 10 章用教师蒸馏估计统一理想损失 (10.1.4) 的不可访问回归目标，得到少步生成器。两阶段可为稳健性进行工程优化，数据和计算效率常仍有竞争力。本章关心更广的问题：没有预训练模型时，能否独立实现稳定、可扩展、高效训练、快速采样及容易体现用户意图的生成?

[1]流映射的数学与历史背景见原式 (4.2.2) 及其邻近讨论。

2021/01	2022/02	2023/03	2023/10	2024/10	2025/05
KD	PD	CM	CTM	sCM	MF
第 10.1 节	第 10.3 节	第 11.2 节	第 11.4 节	第 11.3 节	第 11.5 节

图 11.1: 扩散式流映射学习方法时间线。流映射本身是经典 ODE 解映射；日期只指蒸馏、近似或学习它的现代机器学习方法。蓝色表示特殊映射 $\Psi_{s\to 0}$，橙色表示一般映射 $\Psi_{s\to t}$。日期、顺序与方法名按源，原旋转标注改为可读表格式时间线。来源：原作者。

扩散提供设计原则：以数据逐渐变为简单噪声的连续正向过程为参照，学习逆时间传输、恢复期望边缘。时变表述也比一次性映射更容易在中间步骤引导。因此问：

问题 11.1.1. *没有预训练模型，能否用网络 $G_\theta(\cdot, s, t)$ 学习 $\Psi_{s\to t}$，同时保持高保真生成？*

围绕同一目标，可统一蒸馏与流映射学习（Boffi et al., 2024; Hu et al., 2025）：

$$\mathcal{L}_{\text{oracle}}(\theta) := \mathbb{E}_{s,t}\mathbb{E}_{\mathbf{x}_s\sim p_s}\left[w(s,t)d\big(G_\theta(\mathbf{x}_s,s,t), \Psi_{s\to t}(\mathbf{x}_s)\big)\right].$$

这是式 (10.1.4) 的重列。时间按某分布（如均匀）抽取，$w \geq 0$ 权衡时间对，d 可为平方 ℓ_2。理

$$\mathbf{x}_t\,(\text{时刻}t) \quad \xleftarrow{\Psi_{s\to t}} \quad \mathbf{x}_s\,(\text{时刻}s)$$

图 11.2: 流映射。从时刻 s 的任意状态 $\mathbf{x}_s$ 出发，$\Psi_{s\to t}$ 将其输运到同一理想 PF-ODE 轨迹上时刻 t 的对应点。原图灰色轨迹与时间轴的几何为示意；这里以可编辑状态箭头表示同一映射关系，保留从右噪声端至左数据端的方向。来源：原作者。

想变换为

$$\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du, \qquad \mathbf{v}^*(\mathbf{x}_u, u) = \mathbb{E}[\alpha'_u\mathbf{x}_0 + \sigma'_u\boldsymbol{\epsilon} \mid \mathbf{x}_u],$$

也可用第 6 章其他等价参数化，常用数据或速度预测。理想损失最优时模型精确恢复

$$G^*(\mathbf{x}_s, s, t) = \Psi_{s\to t}(\mathbf{x}_s).$$

源文写为对所有 s, t 及 $\mathbf{x}_s \sim p_s$。[2]

理想映射一般无闭式。可查询预训练教师蒸馏，也可构造自含替代、从头训练；分类依据是训练循环是否调用教师。下面系统介绍兼顾真实性与计算效率的实用方法。

特殊流映射：一致性函数。 一致性模型（CM；Song et al., 2023）是早期代表，学习少步去噪器 $\mathbf{f}_\theta(\cdot, s)$ 近似 $\Psi_{s\to 0}$。沿同一 PF-ODE 轨迹的每个状态都映到同一 0 时刻端点。CM 族（Song et al., 2023; Song and Dhariwal, 2024; Geng et al., 2024; Lu and Song, 2024）的理想目标为

$$\mathcal{L}_{\text{oracle}-\text{CM}}(\theta) := \mathbb{E}_s\mathbb{E}_{\mathbf{x}_s\sim p_s}[w(s)d(\mathbf{f}_\theta(\mathbf{x}_s, s), \Psi_{s\to 0}(\mathbf{x}_s))]. \tag{11.1.0}$$

实践中，以同轨迹上稍早时间的停止梯度网络目标替代不可得理想映射：

$$\Psi_{s\to 0}(\mathbf{x}_s) \approx \mathbf{f}_{\theta^-}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s-\Delta s), \qquad \Delta s > 0.$$

其中中间状态仍需近似：可依预训练模型蒸馏，也可无教师用单点估计。

[2]译注：此恢复结论需所用差异度能分离目标、有效采样/权重覆盖目标时间对、足够表达力及达到理想最优；由期望损失为零通常得到相应测度下几乎处处等式，未将有限网络或零权重区域提升为逐点恢复保证。

一般流映射。 代表包括一致性轨迹模型（CTM）和 Mean Flow（MF）。**CTM**。Kim et al. (2024a) 首先学习任意起止时间的一般映射（沿用源文首创归属），以 Euler 启发参数化：

$$\begin{aligned}\Psi_{s\to t}(\mathbf{x}_s) &= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du \\ &= \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du\right]}_{\approx \mathbf{g}_\theta},\end{aligned}$$

$$G_\theta(\mathbf{x}_s, s, t) := \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}_\theta(\mathbf{x}_s, s, t).$$

用中间时刻停止梯度目标 $G_{\theta^-}(\Psi_{s\to u}(\mathbf{x}_s), u, t)$，$u \in [t, s]$，近似理想映射。中间状态可用教师少步求解，也可从自身参数化构造自诱导教师、从头训练。

MF。Geng et al. (2025a) 以流匹配为基础，建模区间平均漂移

$$\mathbf{h}_\theta(\mathbf{x}_s, s, t) \approx \mathbf{h}^*(\mathbf{x}_s, s, t) := \frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du, \qquad t \le s.$$

对 $(t-s)\mathbf{h}^* = \int_s^t \mathbf{v}^* du$ 关于 s 求导，得自指关系，启发

$$\mathcal{L}_{\mathrm{MF}}(\theta) := \mathbb{E}_s \mathbb{E}_{\mathbf{x}_s\sim p_s}\left[w(s)\|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s, s, t)\|_2^2\right],$$

$$\mathbf{h}^{\mathrm{tgt}}_{\theta^-} := \mathbf{v}^*(\mathbf{x}_s, s) - (s-t)\left[(\partial_{\mathbf{x}}\mathbf{h}_{\theta^-})\mathbf{v}^*(\mathbf{x}_s, s) + \partial_s \mathbf{h}_{\theta^-}\right].$$

实践中理想速度可用预训练流匹配扩散近似，或用正向污染 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$ 的单点条件速度 $\alpha'_s\mathbf{x}_0 + \sigma'_s\boldsymbol{\epsilon}$ 从头训练。

CTM 与 MF 的关系。 它们近似同一路径积分，但参数化替代量不同：

$$\begin{aligned}\Psi_{s\to t}(\mathbf{x}_s) &= \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du\right]}_{\approx \mathbf{g}_\theta} \\ &= \mathbf{x}_s + (t-s)\underbrace{\left[\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du\right]}_{\approx \mathbf{h}_\theta}.\end{aligned}$$

CTM 学习斜率式位移替代，MF 学习平均漂移，均一致地近似定义流映射的同一积分。[3]

后续路线。 第 11.2 节和 11.3 节依次讨论特殊映射的离散与连续 CM，第 11.4 节和 11.5 节讨论一般映射 CTM 与 MF 的参数化、训练与近似。原附录 D.6 的 EDM 提供数据预测网络参数化的系统指南，实证表现强，是 CM 式模型的重要基础。为清楚叙述按概念而非严格年代组织，但图 11.1 保留历史顺序与归属。

11.2 特殊流映射：离散时间一致性模型

重要原则：半群性质。 CM 和 CTM 利用流映射的基本结构设回归目标：

$$\Psi_{u\to t}\circ\Psi_{s\to u} = \Psi_{s\to t}, \qquad \Psi_{s\to s} = I, \qquad \forall s, u, t \in [0, T]. \tag{11.2.1}$$

[3]译注：含 $1/s$、$1/(s-t)$ 的表达需 $s > 0$、$s \neq t$，对角点应以相应极限或边界参数化解释，后文具体讨论。此处源文 MF 损失只显式写 $\mathbb{E}_s$，t 的抽取未在此式指定，照录。

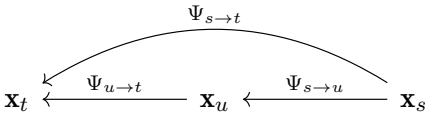


图 11.3: 流映射半群性质。从 s 到 u 再到 t，等同于直接从 s 到 t。三个状态在同一理想 PF-ODE 轨迹；用 tikzcd 重建全部三个映射和方向，灰色轨迹/时间轴示意由节点时间索引表达。来源：原作者。

直觉是沿同一确定轨迹，分段或一次走，都到同一终点；这来自 ODE 初值问题唯一性。[4]

考虑固定 $\mathbf{x}(T)$、逆时间求解 $d\mathbf{x}(\tau)/d\tau = \mathbf{v}^*(\mathbf{x}(\tau),\tau)$ 的轨迹。固定目标 $t=0$，定义一致性函数 $\mathbf{f}^*(\cdot,s) := \Psi_{s\to 0}(\cdot)$。由半群性质可得：

1. **全局一致性：** 同轨迹每点映至同一干净端点，$\mathbf{f}^*(\mathbf{x}(s),s) = \mathbf{x}(0)$，所有 $s\in[0,T]$。因为

$$\mathbf{f}^*(\mathbf{x}(s),s) = \Psi_{s\to 0}(\Psi_{0\to s}(\mathbf{x}(0))) = (\Psi_{s\to 0}\circ\Psi_{0\to s})(\mathbf{x}(0)) = \Psi_{0\to 0}(\mathbf{x}(0)) = \mathbf{x}(0).$$

2. **自一致性：** 同轨迹任意两点输出相同：

$$\mathbf{f}^*(\mathbf{x}(s),s) = \mathbf{f}^*(\mathbf{x}(u),u), \qquad \forall s,u\in[0,T]. \tag{11.2.2}$$

   这是 $\Psi_{s\to 0}\circ\Psi_{0\to s} = \Psi_{u\to 0}\circ\Psi_{0\to u}$ 的重新解释。

3. **局部一致性：** 沿轨迹对时间不变，并满足边界：

$$\frac{d}{ds}\mathbf{f}^*(\mathbf{x}(s),s) = 0, \qquad \mathbf{f}^*(\mathbf{x}(0),0) = \mathbf{x}(0). \tag{11.2.3}$$

   它直接来自全局一致性。

源文称三者等价：均表示沿任意解轨迹，一致性函数给出与起始时间无关的同一端点。[5]

一致性模型的目标。 训练 $\mathbf{f}_\theta : \mathbb{R}^D\times[0,T]\to\mathbb{R}^D$ 近似特殊流映射。[6]同轨迹状态应映到同一 0 端点，等价于半群式取 $t=0, u=s-\Delta s$。实现依有无教师、离散或连续而不同，概括于表 11.1 与图 11.4。

11.2.1 学习一致性函数的离散时间近似

原则上最小化理想目标 (11.1.0)，将每个含噪样本映回它的干净端点。目标不可得，Song et al. (2023) 利用半群性质，将其替为同轨迹稍早时间的停止梯度网络：

$$\Psi_{s\to 0}(\mathbf{x}_s) = \Psi_{s-\Delta s\to 0}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s)) \approx \mathbf{f}_{\theta^-}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s-\Delta s).$$

θ^- 是停止梯度参数。中间状态同样无闭式，分两种近似。

[4]半群性质来自 ODE 初值问题唯一性定理，见附录 A。

[5]译注：若将这些性质作为未知函数的刻画，自一致性本身不固定输出为真实端点；需同时保留恒等边界及所需正则性，才排除常函数等退化解。源定义 $\mathbf{f}^* = \Psi_{s\to 0}$ 已内含该边界。全区间组合还以相应流存在唯一且可在所涉方向定义为条件。

[6]ODE 一致性函数可推广到 SDE 的 $f(\mathbf{x},t)$，使 $f(\mathbf{x}_t,t)$ 关于自然滤过为（局部）鞅，即源文写为 $\mathbb{E}[f(\mathbf{x}_t,t)\mid\mathbf{x}_s] = f(\mathbf{x}_s,s)$，$t\geq s$。此推广由 Daras et al. (2023)、Lai et al. (2023a) 提出/观察，理论联系总结于 Lai et al. (2023b)。译注：局部鞅升级为所写无停时条件期望等式仍需相应可积性条件。

表 11.1: 一致性模型的训练目标。

	蒸馏	从头训练
离散时间	式 (11.2.4)	式 (11.2.6)
连续时间	式 (11.3.5)	式 (11.3.6)

有预训练模型：一致性蒸馏（CD）。 教师只模拟一个逆向 ODE 步：

$$\Psi_{s\to s-\Delta s}(\mathbf{x}_s) \approx \mathrm{Solver}_{s\to s-\Delta s}(\mathbf{x}_s).$$

教师得分 $\mathbf{s}_{\phi^\times} \approx \nabla \log p_s$ 可给出 $s' = s - \Delta s$ 的 DDIM 状态：

$$\begin{aligned}\Psi_{s\to s'}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)\\ &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\mathbf{s}_{\phi^\times}(\mathbf{x}_s, s) =: \widetilde{\mathbf{x}}^{\phi^\times}_{s'}.\end{aligned}$$

在分割 $0 = s_1 < s_2 < \cdots < s_N = T$ 上，CD 损失为

$$\mathcal{L}^N_{\mathrm{CD}}(\theta, \theta^-; \phi^\times) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},i}\left[\omega(s_i)d\big(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\widetilde{\mathbf{x}}^{\phi^\times}_{s_i}, s_i)\big)\right]. \tag{11.2.4}$$

ω 为时变权重，d 为距离。停止梯度参数防止坍缩为常数预测等平凡解（沿用源文动机）。[7]

无预训练模型：一致性训练（CT）。 无教师时可用高方差单点估计。条件期望给出

$$\begin{aligned}\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s) &= \mathbb{E}_{\mathbf{x}_0\sim p(\mathbf{x}_0\mid\mathbf{x}_s)}[\nabla_{\mathbf{x}_s}\log p(\mathbf{x}_s \mid \mathbf{x}_0)]\\ &= \mathbb{E}_{\mathbf{x}_0\sim p(\mathbf{x}_0\mid\mathbf{x}_s)}\left[-\frac{\mathbf{x}_s - \alpha_s\mathbf{x}_0}{\sigma_s^2}\right].\end{aligned}$$

若由配对 $(\mathbf{x}_0, \boldsymbol{\epsilon})$ 构造 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + \sigma_s\boldsymbol{\epsilon}$，单样本估计

$$\widehat{\nabla_{\mathbf{x}}\log p_s}(\mathbf{x}_s) := -\frac{\boldsymbol{\epsilon}}{\sigma_s} = -\frac{\mathbf{x}_s - \alpha_s\mathbf{x}_0}{\sigma_s^2}$$

给定含噪输入时，对干净后验平均为真实得分，恰是 DSM 条件得分目标。代入 DDIM 一步得

$$\begin{aligned}\Psi_{s\to s'}(\mathbf{x}_s) &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\nabla_{\mathbf{x}_s}\log p_s(\mathbf{x}_s)\\ &\approx \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s + \sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)\widehat{\nabla_{\mathbf{x}_s}\log p_s}(\mathbf{x}_s)\\ &= \frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s - \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s}\right)(\mathbf{x}_s - \alpha_s\mathbf{x}_0)\\ &= \alpha_{s'}\mathbf{x}_0 + \sigma_{s'}\boldsymbol{\epsilon}.\end{aligned} \tag{11.2.5}$$

最后使用构造 $\mathbf{x}_s$ 的同一干净样本和噪声，[8]给出无教师离散替代

$$\mathcal{L}^N_{\mathrm{CT}}(\theta, \theta^-) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},i}\left[\omega(s_i)d\big(\mathbf{f}_\theta(\mathbf{x}_{s_{i+1}}, s_{i+1}), \mathbf{f}_{\theta^-}(\mathbf{x}_{s_i}, s_i)\big)\right], \tag{11.2.6}$$

[7]译注：停止梯度本身并不在数学上排除任意常数解；恒等边界、参数化与训练策略也很重要，后面 EDM 边界需一并保留。

[8]最后一步直接由正向污染式作初等代数得到。

其中两状态共享 $(\mathbf{x}_0, \boldsymbol{\epsilon})$。

直接用单点状态近似流会产生高方差。[9]类似 DSM 的条件期望思想仍有帮助，但无偏性发生在通过非线性目标网络和差异度之前，损失未必精确相同。条件一阶误差消去，适当光滑性及矩条件下，剩余差为 $O(\Delta s^2)$。

定理 11.2.1 (CM 与 CT 相差 $O(\Delta s^2)$)**.** 令 $s' = s - \Delta s$，定义

$$\begin{aligned}
\mathcal{L}_{\mathrm{CM}}(\theta, \theta^-) &:= \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}} \left[w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}_{s'}^{\mathrm{DDIM}}, s')) \right], \\
\mathcal{L}_{\mathrm{CT}}(\theta, \theta^-) &:= \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}} \left[w(s) d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}_{s'}, s')) \right], \\
\mathbf{x}_{s'}^{\mathrm{DDIM}} &:= \frac{\alpha_{s'}}{\alpha_s} \mathbf{x}_s + \sigma_s^2 \left(\frac{\alpha_{s'}}{\alpha_s} - \frac{\sigma_{s'}}{\sigma_s} \right) \nabla_{\mathbf{x}_s} \log p_s(\mathbf{x}_s).
\end{aligned}$$

$\mathbf{x}_s$ 与 $\mathbf{x}_{s'}$ 共享同一 $(\mathbf{x}_0, \boldsymbol{\epsilon})$，$\mathbf{x}_0 \sim p_{\mathrm{data}}$、$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$。在上述光滑性和矩条件下，$\mathcal{L}_{\mathrm{CM}} = \mathcal{L}_{\mathrm{CT}} + O(\Delta s^2)$。

证明. 理想 DDIM 更新等于条件均值 $\mathbf{x}_{s'}^{\mathrm{DDIM}} = \mathbb{E}[\mathbf{x}_{s'} \mid \mathbf{x}_s]$，也可对式 (11.2.5) 作后验平均验证。将 $d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\cdot, s'))$ 在此均值展开。因为 $\mathbb{E}[\mathbf{x}_{s'} - \mathbf{x}_{s'}^{\mathrm{DDIM}} \mid \mathbf{x}_s] = 0$，线性项条件平均为零；光滑性与矩假设下剩余期望 Taylor 余项为 $O(\Delta s^2)$。详细推导见原附录 D.5。 □

CD 利用教师初始化和监督，常稳定优化、减少方差；CT 完全从头训练，无预训练依赖，因而是独立生成模型。

实践考虑。 Song et al. (2023) 采用 EDM（Karras et al., 2022；原附录 D.6）污染 $\mathbf{x}_s = \mathbf{x}_0 + s\boldsymbol{\epsilon}$ 和网络参数化

$$\mathbf{f}_\theta(\mathbf{x}, s) = c_{\mathrm{skip}}(s)\mathbf{x} + c_{\mathrm{out}}(s) F_\theta(c_{\mathrm{in}}(s)\mathbf{x}, c_{\mathrm{noise}}(s)),$$

系数见原式 (D.6.5)。它满足 $\mathbf{f}_\theta(\mathbf{x}, 0) = \mathbf{x}$，使无噪声输入与输出相同、强制时间零边界一致性。

11.2.2 一致性模型的采样

离散或连续 CM 训练好后，均可一步或少步生成，见算法 9。

一步生成。 从先验（实际为 $\mathcal{N}(\mathbf{0}, T^2\mathbf{I})$）抽取 $\widehat{\mathbf{x}}_T$，一次求值 $\mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_T, T)$ 生成干净样本。

多步生成。 预选 $T > \tau_1 > \cdots > \tau_{M-1} = 0$，交替注入噪声与较早时刻的一致性长跳，逐渐细化：

$$\widehat{\mathbf{x}}_T \xrightarrow{\text{长跳：干净样本}} \mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_T, T) \xrightarrow{\text{加噪至}\tau_1} \widehat{\mathbf{x}}_{\tau_1} \downarrow \text{长跳：干净样本}$$
$$\cdots \xleftarrow{\text{加噪至}\tau_2} \mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_{\tau_1}, \tau_1)$$

[9]单点条件得分可视为一次 Monte Carlo 估计。给定 $\mathbf{x}_s$，对一般难解的干净后验 $p(\cdot \mid \mathbf{x}_s)$ 平均，恢复真实得分，故为条件无偏。

算法 9 CM 的一步或多步采样

Require: 模型 $\mathbf{f}_{\theta^\times}(\cdot,\cdot)$；时间序列 $T>\tau_1>\cdots>\tau_{M-1}=0$；初始噪声 $\widehat{\mathbf{x}}_T$

if 一步生成 **then**
  $\mathbf{x}\leftarrow\mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_T,T)$
else
  $\mathbf{x}\leftarrow\mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_T,T)$
  for $m=1,\dots,M-1$ **do**
    抽取 $\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$
    $\widehat{\mathbf{x}}_{\tau_m}\leftarrow\alpha_{\tau_m}\mathbf{x}+\sigma_{\tau_m}\boldsymbol{\epsilon}$
    $\mathbf{x}\leftarrow\mathbf{f}_{\theta^\times}(\widehat{\mathbf{x}}_{\tau_m},\tau_m)$
  end for
end if
输出： $\mathbf{x}$

11.3 特殊流映射：连续时间一致性模型

离散形式固定网格、只在抽样点训练；连续视角将流映射定义于所有时间，摆脱任意离散选择，更直接对应动力学，帮助减少离散积分误差，使一致性原则覆盖连续时间，而非仅选定步骤。[10]

11.3.1 连续时间一致性模型

从式 (11.2.3)，链式法则给出

$$\frac{d}{ds}\mathbf{f}^*(\mathbf{x}(s),s)=0\quad\Longleftrightarrow\quad(\nabla_{\mathbf{x}}\mathbf{f}^*)(\mathbf{x}(s),s)\cdot\underbrace{\frac{d}{ds}\mathbf{x}(s)}_{\text{ODE 速度}}+\frac{\partial}{\partial s}\mathbf{f}^*(\mathbf{x}(s),s)=0,\tag{11.3.1}$$

轨迹满足 $d\mathbf{x}(s)/ds=\mathbf{v}^*(\mathbf{x}(s),s)$。一致性函数沿任意 ODE 解保持常数，实际速度可用教师或 $\alpha_s'\mathbf{x}_0+\sigma_s'\boldsymbol{\epsilon}$ 单点估计。

自然思路是像 PINNs（Raissi, 2018; Boffi et al., 2024）直接最小化微分残差

$$\min_\theta\ \mathbb{E}_{s,\mathbf{x}_s\sim p_s}\|\partial_s\mathbf{f}_\theta(\mathbf{x}_s,s)+(\partial_{\mathbf{x}}\mathbf{f}_\theta(\mathbf{x}_s,s))\mathbf{v}^*(\mathbf{x}_s,s)\|_2^2.$$

但 Song et al. (2023)、Lu and Song (2024) 实际使用目标网络式一致性目标而非直接残差优化。因此问离散损失在 $\Delta s\to 0$ 时是否有有意义的无穷小对应。考虑

$$\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-):=\mathbb{E}\left[\omega(s)\|\mathbf{f}_\theta(\mathbf{x}_s,s)-\mathbf{f}_{\theta^-}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s),s-\Delta s)\|_2^2\right].\tag{11.3.2}$$

均匀分割步长 $\Delta s_N=T/(N-1)$ 随 $N\to\infty$ 趋零。下述比较在停止梯度目标与在线网络重合点进行。

[10]译注：此处是理想连续目标的表述；有限网络、有限训练采样和实际优化本身并不因此自动保证全时刻精确一致性。

命题 11.3.1 (连续时间一致性训练)**.** *在 $\theta=\theta^-$ 处，*

$$\lim_{\Delta s\to 0}\frac{1}{\Delta s}\,\nabla_\theta\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-)\big|_{\theta=\theta^-}=\nabla_\theta\mathcal{L}_{\mathrm{CM}}^{\infty}(\theta,\theta^-)\big|_{\theta=\theta^-},$$

其中 $\mathcal{L}_{\mathrm{CM}}^{\infty}:=\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}[2\omega(s)\mathbf{f}_\theta^\top(\mathbf{x}_s,s)\cdot\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)]$，全导数满足

$$\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)=\partial_s\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)+(\partial_{\mathbf{x}}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s))\mathbf{v}^*(\mathbf{x}_s,s).\tag{11.3.3}$$

证明. 在 $(\mathbf{x}_s,s)$ 对停止梯度目标一阶 Taylor 展开。于 $\theta=\theta^-$ 比较时，零阶不匹配项消失；缩放后的离散梯度趋向学生参数导数与目标沿轨迹切向变化的内积梯度：

$$\lim_{\Delta s\to 0}\frac{1}{\Delta s}\,\nabla_\theta\mathcal{L}_{\mathrm{CM}}^{\Delta s}\big|_{\theta=\theta^-}=\nabla_\theta\mathbb{E}\left[2\omega(s)\mathbf{f}_\theta^\top(\mathbf{x}_s,s)\cdot\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)\right]\Big|_{\theta=\theta^-}.$$

详细证明见原附录 D.5。 □

∇_θ 不作用于停止梯度的 θ^-，切向项是沿理想轨迹的全导数，不只是偏时间导数。忽略因子 2，可用以下伪目标梯度训练：

$$\mathcal{L}_{\mathrm{CM}}^{\infty}(\theta,\theta^-):=\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\omega(s)\mathbf{f}_\theta^\top(\mathbf{x}_s,s)\cdot\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)\right].\tag{11.3.4}$$

译注：这是比较点上的半梯度极限，而非两个损失的值相等，亦非直接平方微分残差目标。Taylor 与期望极限交换需适当光滑性和可积界。

11.3.2 训练连续时间一致性模型

实际需近似切向项中的不可得理想速度。训练后按第 11.2.2 节同样采样。

连续时间一致性蒸馏。 若预训练速度 $\mathbf{v}_{\phi^\times}\approx\mathbf{v}^*$ 可用，取

$$\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)\approx\partial_s\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)+(\partial_{\mathbf{x}}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s))\mathbf{v}_{\phi^\times}(\mathbf{x}_s,s).\tag{11.3.5}$$

所得目标记 $\mathcal{L}_{\mathrm{CM}}^{\infty}(\theta,\theta^-;\phi^\times)$，相应极限重列为

$$\lim_{N\to\infty}\Delta s_N^{-1}\nabla_\theta\mathcal{L}_{\mathrm{CD}}^{N}(\theta,\theta^-;\phi^\times)=\nabla_\theta\mathcal{L}_{\mathrm{CD}}^{\infty}(\theta,\theta^-;\phi^\times).$$

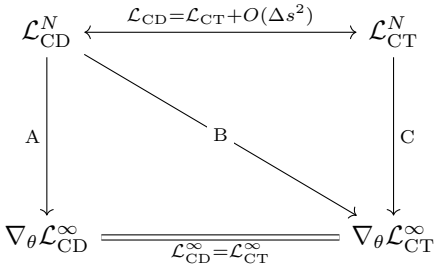
连续时间从头训练。 无教师时用单点条件速度：

$$\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)\approx\partial_s\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)+(\partial_{\mathbf{x}}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s))(\alpha_s'\mathbf{x}_0+\sigma_s'\boldsymbol{\epsilon}).\tag{11.3.6}$$

记目标 $\mathcal{L}_{\mathrm{CT}}^{\infty}(\theta,\theta^-)$，相应极限为 $\lim_{N\to\infty}\Delta s_N^{-1}\nabla_\theta\mathcal{L}_{\mathrm{CT}}^{N}=\nabla_\theta\mathcal{L}_{\mathrm{CT}}^{\infty}$。[11]

至此表 11.1 各基本方法已给出。图 11.4 汇总离散/连续和有无预训练教师的联系。切向全导数常导致训练不稳。下一可选小节介绍 sCM（Lu and Song, 2024）的简化、稳定及扩展技巧。

[11]译注：此两行按源文重列，承接命题 11.3.1 的同网络比较点与因子约定；源文重列未再次写 $|_{\theta=\theta^-}$，不能据此推广为任意独立目标参数下的极限。



A, B, C：$\lim_{N\to\infty}\Delta s_N^{-1}\nabla_\theta$。A 为原文定理 5，B 与 C 为原文定理 6；均保留正文中的比较点与假设。

图 11.4: 平方 ℓ_2 距离下离散/连续 CD 与 CT 的关系。顶部关系对应本章定理 11.2.1；图中原文定理 5、6 沿用 Song et al. (2023) 的编号，非本书定理号。凡涉及 CT 的定理，假定教师得分完美：$\mathbf{s}_{\phi^\times}\equiv\nabla\log p_t$。连续 CT 目标见式 (11.3.4)，连续 CD 切向近似见式 (11.3.5)。由源图四类目标、三条极限关系及上下等式重建 tikzcd；梯度极限保留比较点限定。来源：原作者。

11.3.3 （可选）连续时间 CT 的实践考虑

我们关心无需外部教师的独立生成模型。直接用式 (11.3.4) 常因切向项时间导数过大或无界而梯度爆炸。适当参数化与稳定策略很重要（Geng et al., 2025b; Lu and Song, 2024）。与原第 6.2.2 节一样，需区分并设计过程、参数化、时间权重和采样分布。

扩散过程。 Lu and Song (2024) 采用三角调度，数学上可由原参数化转换，却使目标结构与尺度分离更清楚。[12]并依 EDM 引入数据标准差 σ_d：

$$\mathbf{x}_s := \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}, \qquad \mathbf{z}\sim\mathcal{N}(\mathbf{0},\sigma_d^2\mathbf{I}). \tag{11.3.7}$$

任意原高斯过程可先重写为 $\mathbf{x}_s = \alpha_s\mathbf{x}_0 + (\sigma_s/\sigma_d)(\sigma_d\boldsymbol{\epsilon})$，定义 $\mathbf{z} := \sigma_d\boldsymbol{\epsilon}$，新系数 $\alpha'_s := \alpha_s$、$\sigma'_s := \sigma_s/\sigma_d$，再按原式 (6.3.5) 的归一化映到三角形式。[13]

参数化。 沿 EDM 设计原则，取 $\mathbf{f}_\theta = c_{\mathrm{skip}}\mathbf{x} + c_{\mathrm{out}}F_\theta(c_{\mathrm{in}}\mathbf{x}, c_{\mathrm{noise}})$，系数为 $c_{\mathrm{skip}}=\cos s$、$c_{\mathrm{out}}=-\sigma_d\sin s$、$c_{\mathrm{in}}=1/\sigma_d$，推导见 Lu and Song (2024) 附录 B。默认 $c_{\mathrm{noise}}(s)=s$，时间导数有界。因此

$$\mathbf{f}_\theta(\mathbf{x},s) = \cos(s)\mathbf{x} - \sin(s)\sigma_d F_\theta\left(\frac{\mathbf{x}}{\sigma_d}, c_{\mathrm{noise}}(s)\right). \tag{11.3.8}$$

始终满足 $\mathbf{f}_\theta(\mathbf{x},0)=\mathbf{x}$。

稳定切向训练的技巧。 在上述参数化下，伪目标梯度为

$$\nabla_\theta\mathcal{L}^\infty_{\mathrm{CT}}(\theta,\theta^-) = \nabla_\theta\mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[-\omega(s)\sigma_d\sin(s)F_\theta^\top\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right)\cdot\frac{d\mathbf{f}_{\theta^-}}{ds}(\mathbf{x}_s,s)\right]. \tag{11.3.9}$$

[12]三角函数及导数有界，有助避免切向项尺度爆炸；更详细机制如下。

[13]译注：此句中的撇号是源文临时的新系数标记，不是前后公式的时间导数；同时包含状态归一化/时间变换，不能理解为不变原状态时间下任意系数自动等于 cos/sin。

理论上此梯度可能足够，但 Lu and Song (2024) 观察到切向函数造成实际不稳：

$$\underbrace{\frac{d\mathbf{f}_{\theta^-}}{ds}(\mathbf{x}_s,s)}_{\text{A}} = -\cos(s)\left[\sigma_d F_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_d},s\right)-\frac{d\mathbf{x}_s}{ds}\right] - \sin(s)\left[\mathbf{x}_s+\sigma_d\frac{d}{ds}F_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_d},c_{\text{noise}}(s)\right)\right].$$

尤其 B 项中 $\sin(s)\frac{d}{ds}F_{\theta^-}=\sin(s)\nabla_{\mathbf{x}_s}F_{\theta^-}\frac{d\mathbf{x}_s}{ds}+\sin(s)\partial_s F_{\theta^-}$，不稳定成分为

$$\sin(s)\partial_s F_{\theta^-}=\sin(s)\underbrace{\frac{\partial c_{\text{noise}}(s)}{\partial s}\cdot\frac{\partial\,\text{emb}(c_{\text{noise}})}{\partial c_{\text{noise}}}\cdot\frac{\partial F_{\theta^-}}{\partial\,\text{emb}(c_{\text{noise}})}}_{\text{C}}. \tag{11.3.10}$$

这里用位置或 Fourier 嵌入，链为 $s\mapsto c_{\text{noise}}(s)\mapsto \text{emb}(c_{\text{noise}}(s))\mapsto F_{\theta^-}(\mathbf{x}_s/\sigma_d,\text{emb}(c_{\text{noise}}(s)))$。缓解技巧有：

- **A：切向归一化**。用 $\frac{(d/ds)\mathbf{f}_{\theta^-}}{\|(d/ds)\mathbf{f}_{\theta^-}\|_2+c}$ 替代切向量，$c>0$ 经验设置；或逐分量裁剪至 $[-1,1]$，限制方差。
- **B：切向预热**。可选将可能不稳的 $\sin(s)(\mathbf{x}_s+\sigma_d(d/ds)F_{\theta^-})$ 的系数替为 $r\sin(s)$，r 在最初若干训练迭代由 0 线性升至 1。
- **C：时间嵌入**。使用更小幅度参数控制嵌入对时间的导数；同样原因取 $c_{\text{noise}}(s)=s$，其导数为有界常数 1。

往往还需改善归一化的架构改动，以及高效 JVP 计算切向导数，超出此处范围。

时间权重函数。 手工设计 $\omega(s)$ 可能次优。仿照 EDM-2（Karras et al., 2024），Lu and Song (2024) 学习自适应权重 $\omega_\varphi(s)$，平衡各时间的损失尺度。式 (11.3.9) 形式为 $\mathbb{E}[F_\theta^\top\mathbf{y}]$，其中 $\mathbf{y}=-\omega(s)\sigma_d\sin(s)(d/ds)\mathbf{f}_{\theta^-}$ 不依赖在线参数。源文据此写为

$$\nabla_\theta\mathbb{E}[F_\theta^\top\mathbf{y}]=\frac{1}{2}\nabla_\theta\mathbb{E}\|F_\theta-F_{\theta^-}+\mathbf{y}\|_2^2.$$

译注：该梯度等式按前文同网络比较点 $\theta=\theta^-$ 理解；任意不同网络下右端还含 $(\partial_\theta F_\theta)^\top(F_\theta-F_{\theta^-})$，不能把它作为所有参数的恒等式。

据此额外训练权重网络，最小化

$$\min_\varphi\ \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega_\varphi(s)}}{D}\|F_\theta-F_{\theta^-}+\mathbf{y}\|_2^2-\omega_\varphi(s)\right].$$

对逐点权重求导，最优 $\omega^*(s)$ 满足

$$\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega^*(s)}}{D}\|F_\theta-F_{\theta^-}+\mathbf{y}\|_2^2\right]=1,\qquad \text{几乎处处的}s. \tag{11.3.11}$$

无约束逐点权重使每个时间的期望重标损失归一化，从而平衡不同时间的训练尺度、改善稳定性。[14]

[14]译注：此条件归一化的是条件期望损失，不单独证明所有时间或样本梯度方差必减；最优有限权重还要求相应条件损失有限正。经验改善沿源文陈述。

时间采样分布。 从对数正态提议抽取三角时钟（Karras et al., 2022）：

$$\log(\sigma_d \tan s) \sim \mathcal{N}(\cdot; P_{\text{mean}}, P_{\text{std}}^2), \tag{11.3.12}$$

两 P 是超参数。可取先验权重 $\omega(s) = 1/(\sigma_d \tan s)$，于是

$$-\omega(s)\sigma_d \sin(s) \frac{d}{ds}\mathbf{f}_{\theta^-} = -\cos(s)\frac{d}{ds}\mathbf{f}_{\theta^-}.$$

译注： 原算法 10 输入及初始化显式包含预训练模型，即使选择 CT 分支也保留该初始化。本

算法 10 连续时间一致性模型 sCM 的训练

Require: 数据 $\mathcal{D}$，标准差 σ_d；预训练扩散 F_{pretrain} 及参数 θ_{pretrain}；模型 F_θ、权重 ω_φ；学习率 η；提议 $P_{\text{mean}}, P_{\text{std}}$；常数 c；预热次数 H

$\theta \leftarrow \theta_{\text{pretrain}}$，Iters $\leftarrow 0$
repeat
  $\mathbf{x}_0 \sim \mathcal{D}$，$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma_d^2\mathbf{I})$，$\tau \sim \mathcal{N}(P_{\text{mean}}, P_{\text{std}}^2)$，$s \leftarrow \arctan(e^\tau/\sigma_d)$
  $\mathbf{x}_s \leftarrow \cos(s)\mathbf{x}_0 + \sin(s)\mathbf{z}$
  if 一致性训练 **then**
    $d\mathbf{x}_s/ds \leftarrow \cos(s)\mathbf{z} - \sin(s)\mathbf{x}_0$
  else
    $d\mathbf{x}_s/ds \leftarrow \sigma_d F_{\text{pretrain}}(\mathbf{x}_s/\sigma_d, s)$
  end if
  $r \leftarrow \min(1, \text{Iters}/H)$ ▷ 切向预热
  $\mathbf{w} \leftarrow -\cos^2(s)(\sigma_d F_{\theta^-} - d\mathbf{x}_s/ds)$
    $\quad - r\cos(s)\sin(s)(\mathbf{x}_s + \sigma_d\, dF_{\theta^-}/ds)$
  $\mathbf{w} \leftarrow \mathbf{w}/(\|\mathbf{w}\| + c)$ ▷ 切向归一化
  $\mathcal{L}_{\text{sCM}} \leftarrow \dfrac{e^{\omega_\varphi(s)}}{D}\|F_\theta(\mathbf{x}_s/\sigma_d, s) - F_{\theta^-}(\mathbf{x}_s/\sigma_d, s) - \mathbf{w}\|_2^2 - \omega_\varphi(s)$
  $(\theta, \varphi) \leftarrow (\theta, \varphi) - \eta\nabla_{\theta,\varphi}\mathcal{L}_{\text{sCM}}$
  Iters $\leftarrow$ Iters $+ 1$
until 收敛

章的 “从头” 分类主要据训练循环是否查询教师，不能据此声称所列算法为随机初始化、完全未用预训练权重。θ^- 的更新/同步规则源伪代码未列，照录保留，不补造 EMA 策略。

训练目标小结。 综合可写最终损失

$$\mathcal{L}_{\text{sCM}}(\theta, \varphi) := \mathbb{E}_{s,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\frac{e^{\omega_\varphi(s)}}{D}\left\|F_\theta\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right) - F_{\theta^-}\left(\frac{\mathbf{x}_s}{\sigma_d}, s\right) - \cos(s)\frac{d\mathbf{f}_{\theta^-}}{ds}(\mathbf{x}_s, s)\right\|_2^2 - \omega_\varphi(s)\right].$$

按式 (11.3.12) 抽时间、式 (11.3.7) 构造状态，所得模型称 sCM，流程见算法 10；预热/归一化按算法中的稳定版本应用。

11.4 一般流映射：一致性轨迹模型

CTM（Kim et al., 2024a）是最早学习一般 $\Psi_{s\to t}$ 的方法之一。

实践设定。 与 CM 一样，原 CTM 采用 EDM，$\alpha_t = 1, \sigma_t = t$。数据预测 PF-ODE 为

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \frac{\mathbf{x}(\tau) - \mathbb{E}[\mathbf{x} \mid \mathbf{x}(\tau)]}{\tau}, \qquad \Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \frac{\mathbf{x}_\tau - \mathbb{E}[\mathbf{x} \mid \mathbf{x}_\tau]}{\tau} d\tau.$$

一步 Euler 给出

$$\mathbf{x}_{s\to t}^{\text{Euler}} = \mathbf{x}_s - (s-t)\frac{\mathbf{x}_s - \mathbb{E}[\mathbf{x} \mid \mathbf{x}_s]}{s} = \frac{t}{s}\mathbf{x}_s + \left(1 - \frac{t}{s}\right)\mathbb{E}[\mathbf{x} \mid \mathbf{x}_s],$$

启发下述参数化。[15]EDM 只是简洁例子，CTM 也可用一般线性高斯核，以速度形式 $\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du$ 表达，以下用此一般形式。

11.4.1 用于灵活转移学习的 CTM 参数化

将理想映射改写为输入与残差的凸组合：$\Psi_{s\to t} = \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}^*$，其中

$$\mathbf{g}^*(\mathbf{x}_s, s, t) := \mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du. \tag{11.4.1}$$

相应网络为

$$G_\theta(\mathbf{x}_s, s, t) := \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\mathbf{g}_\theta(\mathbf{x}_s, s, t). \tag{11.4.2}$$

学习 $\mathbf{g}_\theta \approx \mathbf{g}^*$ 即使 $G_\theta \approx \Psi$，符合统一式 (10.1.4)，并天然满足 $G_\theta(\mathbf{x}_s, s, s) = \mathbf{x}_s$。

参数化的优点。 考察 $t \to s$：

命题 11.4.1 ($\mathbf{g}^*$ 的性质)**.** *1.* 恢复扩散模型：$\mathbf{g}^*(\mathbf{x}_s, s, s) = \lim_{t\to s}\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s)$；

2. 积分表示：$\mathbf{g}^*(\mathbf{x}_s, s, t) = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + O(|t-s|)$。

证明. 定义给出 $\lim_{t\to s}\mathbf{g}^* = \mathbf{x}_s - s\lim_{t\to s}\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_\tau, \tau)d\tau = \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s)$。再由 Taylor 展开，

$$\begin{aligned}\mathbf{g}^*(\mathbf{x}_s, s, t) &= \mathbf{x}_s - \frac{s}{s-t}\int_t^s \mathbf{v}^*(\mathbf{x}_\tau, \tau)d\tau \\ &= \mathbf{x}_s - \frac{s}{s-t}[(s-t)\mathbf{v}^*(\mathbf{x}_s, s) + O((t-s)^2)] \\ &= \mathbf{x}_s - s\mathbf{v}^*(\mathbf{x}_s, s) + O(|t-s|).\end{aligned}$$

□

故估计 $\mathbf{g}^*$ 同时近似有限转移与局部瞬时速度；它可解释为去噪器式量加 Taylor 残差。$t < s$ 时，学习 $G_\theta \approx \Psi$ 等价于带非零因子 $(s-t)/s$ 学习残差；对角值编码 $\mathbf{v}^* = (\mathbf{x}_s - \mathbf{g}^*(\mathbf{x}_s, s, s))/s$，可用下面扩散损失直接监督。因此单个参数化兼顾长跳与局部动力学。

11.4.2 CTM 的一致性损失

理想映射一般无闭式，利用 $s \geq u \geq t$ 下的半群性质构造可行目标。

[15]时间仿射调度（如 $(1,t)$、$(1-t,t)$）中，原时间 Euler 恰与确定性 DDIM 重合；一般调度只一阶一致，见第 9.2.2 节。

蒸馏训练。 给定预训练 $\mathbf{v}_{\phi^\times} \approx \mathbf{v}^*$，经验 ODE 为

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \mathbf{v}_{\phi^\times}(\mathbf{x}_\tau, \tau). \tag{11.4.3}$$

令学生匹配 $\mathrm{Solver}_{s\to t}(\mathbf{x}_s; \phi^\times)$。强教师下，数值解近似理想映射，见 Kim et al. (2024a) 命题 3、4。[16]

全区间求解昂贵，于是以软一致性匹配比较直接学生输出与混合路径：先从 s 用教师走到随机 $u \sim \mathcal{U}[t, s)$，再用停止梯度学生跳到 t，

$$\underbrace{G_\theta(\mathbf{x}_s, s, t)}_{\approx \Psi_{s\to t}(\mathbf{x}_s)} \approx \underbrace{G_{\theta^-}(\mathrm{Solver}_{s\to u}(\mathbf{x}_s; \phi^\times), u, t)}_{\approx \Psi_{u\to t}(\Psi_{s\to u}(\mathbf{x}_s))}. \tag{11.4.4}$$

变化 u 在全局/局部监督间插值：$u = t$ 时目标退为全教师区间转移；$u = s - \Delta s$ 时仅用短教师步，且 $t = 0$ 退化为一致性蒸馏。

为兼顾轨迹与样本质量，两预测再经停止梯度学生映至 0，在特征空间距离 d 中比较：

$$\begin{aligned}
\mathbf{x}_{\mathrm{est}}(\mathbf{x}_s, s, t) &:= G_{\theta^-}(G_\theta(\mathbf{x}_s, s, t), t, 0), \\
\mathbf{x}_{\mathrm{target}}(\mathbf{x}_s, s, u, t) &:= G_{\theta^-}(G_{\theta^-}(\mathrm{Solver}_{s\to u}(\mathbf{x}_s; \phi^\times), u, t), t, 0).
\end{aligned}$$

损失为

$$\mathcal{L}_{\mathrm{consist}}(\theta; \phi^\times) := \mathbb{E}_{s\in[0,T]}\mathbb{E}_{t\in[0,s]}\mathbb{E}_{u\in[t,s)}\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{\mathbf{x}_s|\mathbf{x}_0}[d(\mathbf{x}_{\mathrm{est}}, \mathbf{x}_{\mathrm{target}})]. \tag{11.4.5}$$

从头训练。 利用对角残差与速度关系，将理想对角量替为自身停止梯度估计，得到自诱导经验 ODE

$$\frac{d\mathbf{x}(\tau)}{d\tau} = \frac{\mathbf{x}(\tau) - \mathbf{g}_{\theta^-}(\mathbf{x}(\tau), \tau, \tau)}{\tau}, \qquad \tau > 0. \tag{11.4.6}$$

解它可得可计算转移目标 $\mathrm{Solver}_{s\to t}(\mathbf{x}_s; \theta^-)$。只有对角估计准确恢复目标局部动力学，才接近理想流；下面扩散损失直接监督该量。

同样可缩短求解为 $G_\theta(\mathbf{x}_s, s, t) \approx G_{\theta^-}(\mathrm{Solver}_{s\to u}(\mathbf{x}_s; \theta^-), u, t)$，区别只是外部教师换成自诱导教师。两预测仍映到 0，目标改为 $\widehat{\mathbf{x}}_{\mathrm{target}} := G_{\theta^-}(G_{\theta^-}(\mathrm{Solver}_{s\to u}(\mathbf{x}_s; \theta^-), u, t), t, 0)$，无预训练一致性损失为

$$\mathcal{L}_{\mathrm{consist}}(\theta; \theta^-) := \mathbb{E}_{s\in[0,T]}\mathbb{E}_{t\in[0,s]}\mathbb{E}_{u\in[t,s)}\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{\mathbf{x}_s|\mathbf{x}_0}[d(\mathbf{x}_{\mathrm{est}}, \widehat{\mathbf{x}}_{\mathrm{target}})]. \tag{11.4.7}$$

概念上是模型提供短程教师信号、学生学习完整转移的内部自蒸馏。

11.4.3 CTM 的辅助损失

仅优化教师生成目标的（自）蒸馏缺少真实数据直接监督，可能不及教师。CTM 自然加入数据驱动正则，如 DSM 与 GAN 项（Goodfellow et al., 2014）。

[16]译注：教师不完美时仍有模型近似误差，不能仅凭求解精确就声称恢复理想流；后面的“精确似然”同样指所定义经验 ODE 及适当可逆/可积条件。

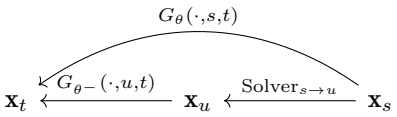


图 11.5: CTM 半群匹配。$s \geq u \geq t$ 时，短求解器片段 $s \to u$ 接 CTM 长跳至 t，近似直接 CTM 映射 $s \to t$。求解器可来自预训练扩散或 CTM 自诱导教师。以 tikzcd 保留全部转移和方向，图中 “沿轨迹匹配” 由上下两条路径表示。来源：改编自 Kim et al. (2024a)。

扩散损失的自然整合。 更精确地，是条件流匹配损失（原式 (5.2.10)）。对角关系诱导 $\mathbf{v}_\theta(\mathbf{x}_s, s) := [\mathbf{x}_s - \mathbf{g}_\theta(\mathbf{x}_s, s, s)]/s$。在线性高斯路径上，

$$\mathcal{L}_{\mathrm{DM}}(\theta) := \mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},s}\left[w(s)\|\mathbf{v}_\theta(\mathbf{x}_s, s) - (\alpha'_s\mathbf{x}_0 + \sigma'_s\boldsymbol{\epsilon})\|_2^2\right]. \tag{11.4.8}$$

$t \approx s$ 时映射参数化的因子 $1 - t/s$ 很小，可能削弱梯度、拖慢学习；直接局部速度监督提供更强信号、稳定训练。一致性损失匹配轨迹（零阶），此损失匹配斜率（一阶）。

（可选）GAN 损失。 回归可能过度平滑，CTM 可加入对抗项，鼓励真实锐利细节。判别器 D_ζ 区分真实 $\mathbf{x}_0$ 与生成 $\mathbf{x}_{\mathrm{est}}$：

$$\begin{aligned}\mathcal{L}_{\mathrm{GAN}}(\theta,\zeta) := \mathbb{E}_{\mathbf{x}_0}[\log D_\zeta(\mathbf{x}_0)] \\ + \mathbb{E}_{s\in[0,T]}\mathbb{E}_{t\in[0,s]}\mathbb{E}_{\mathbf{x}_0}\mathbb{E}_{\mathbf{x}_s|\mathbf{x}_0}\left[\log(1 - D_\zeta(\mathbf{x}_{\mathrm{est}}(\mathbf{x}_s, s, t)))\right].\end{aligned}$$

对判别器最大化、生成器最小化。直观上判别器是自适应感知距离；理想 GAN 理论中对应数据与生成分布的 Jensen–Shannon 匹配，可使保真度超越教师。

整体 CTM 目标。 统一为

$$\mathcal{L}_{\mathrm{CTM}}(\theta,\zeta) := \mathcal{L}_{\mathrm{consist}}(\theta;\phi^\times/\theta^-) + \lambda_{\mathrm{DM}}\mathcal{L}_{\mathrm{DM}}(\theta) + \lambda_{\mathrm{GAN}}\mathcal{L}_{\mathrm{GAN}}(\theta,\zeta).$$

教师可为外部预训练或自身停止梯度模型。回归分量提供强正则，可选 GAN 改善细节而保持稳定（Kim et al., 2024b；按源实证陈述）。

11.4.4 CTM 的灵活采样

一般映射支持任意时刻到任意较早时刻。CTM 的 γ 采样调控随机性，还可复用扩散的 ODE 求解、似然计算等技术。固定 $T = \tau_0 > \tau_1 > \cdots > \tau_M = 0$。

γ 采样机制。 这是一般流映射自然诱导的采样族，包含 CM 多步与类似 ODE 时间步的确定性采样。γ 控制生成语义变化，为不同下游任务提供灵活性：

- $\gamma = 1$：等于 CM 多步，只需特殊映射 $\Psi_{s\to 0}$，全随机，改变步数可能改变语义；
- $\gamma = 0$：完全确定性，跟随 PF-ODE 轨迹。直接学习长跳避免显式数值求解器的离散误差；但仍有学习映射近似误差，不能据此称样本精确；
- $0 < \gamma < 1$：两端之间插值，注入可控随机性，需一般映射。

译注： 算法及先验形式针对本节原 EDM $\alpha = 1, \sigma = t$，不能不变地套到任意流匹配或高斯调度；其他调度须相应调整加噪系数。

算法 11 CTM 的 γ 采样

Require: 训练模型 $G_{\theta^\times}$；$\gamma \in [0,1]$；递减网格 $T=\tau_0>\cdots>\tau_M=0$

从 $\mathbf{x}_{\tau_0}\sim p_{\text{prior}}=\mathcal{N}(\mathbf{0},T^2\mathbf{I})$ 开始

for $n=0,\dots,M-1$ **do**

  $\widetilde{\tau}_{n+1}\leftarrow\sqrt{1-\gamma^2}\,\tau_{n+1}$

  去噪：$\mathbf{x}_{\widetilde{\tau}_{n+1}}\leftarrow G_{\theta^\times}(\mathbf{x}_{\tau_n},\tau_n,\widetilde{\tau}_{n+1})$

  扩散：$\mathbf{x}_{\tau_{n+1}}\leftarrow\mathbf{x}_{\widetilde{\tau}_{n+1}}+\gamma\tau_{n+1}\boldsymbol{\epsilon}$，$\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\mathbf{I})$

end for

输出： $\mathbf{x}_{\tau_M}$

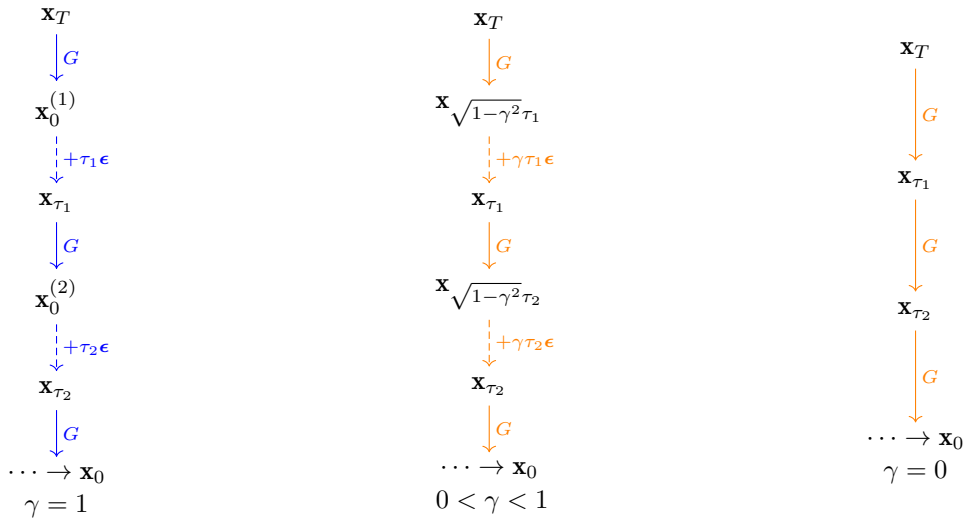


图 11.6: 不同 γ 的采样。每步先网络去噪到 $\sqrt{1-\gamma^2}\tau_{n+1}$，再加噪至 τ_{n+1}。左、中、右分别为全随机、部分随机和确定性。原图照片缩略节点以状态符号替代、转移按时间序列展开；实线去噪、虚线加噪的类型与蓝/橙区分保留，没有生成替代样本。来源：改编自 Kim et al. (2024a)。

γ 采样分析。 CTM 实证中，CM 多步在 $M \geq 4$ 后质量下降。源文解释为非零 γ 下长跳小失配叠加，提出下述非正式界。

命题 11.4.2 (非正式：两步 γ 采样)**.** *设 $\tau \in (0,T)$、$\gamma \in [0,1]$，$p_{\theta^*,2}$ 为从 p_T 出发、以最优 CTM 沿 $T \to \sqrt{1-\gamma^2}\tau \to \tau \to 0$ 采样所得密度。则原文写为*

$$D_{\mathrm{TV}}(p_{\mathrm{data}}, p_{\theta^*,2}) = O\left(\sqrt{T - \sqrt{1-\gamma^2}\,\tau + \tau}\right).$$

D_{TV} 是全变差。

证明. 一般 M 步情形见 Kim et al. (2024a) 定理 8。 □

译注： 保留源非正式命题、最优模型记号及根号覆盖范围；此段未给隐藏常数、模型类和误差假设，不能将其视为对任意网络、任意尺度的完整普适界，更不代表本工程验证了外引定理。

源文总结：$\gamma = 1$ 每步从 τ_n 长跳至 0，误差累积量级 $O(\sqrt{T + \tau_1 + \cdots + \tau_M})$；$\gamma = 0$ 去除时间重叠，给出较紧 $O(\sqrt{T})$，实证中增步改善质量且未引入不稳，形成有利速度–质量权衡。这些为所引工作的界与实验范围，不升为普适单调质量结论。

CTM 支持扩散推断。 对角 $\mathbf{g}_\theta(\cdot, s, s)$ 提供得分或去噪信息，因此可使用第 4 章似然计算与第 9 章 DDIM/DPM 等高级采样器。

11.5 一般流映射：Mean Flow

一般流映射也有多种参数化与训练目标。MF（Geng et al., 2025a）是较晚代表，提供另一种有原则的学习视角。

11.5.1 Mean Flow 的建模与训练

与基于 EDM 的 CM/CTM 不同，MF 以流匹配调度 $\alpha_t = 1 - t, \sigma_t = t$、$t \in [0,1]$ 为基础。它不直接参数化流映射，而学习 $t < s$ 区间的平均漂移 $\mathbf{h}^*(\mathbf{x}_s, s, t) := (t-s)^{-1} \int_s^t \mathbf{v}^*(\mathbf{x}_u, u) du$。理想目标为

$$\mathbb{E}_{t<s} \mathbb{E}_{\mathbf{x}_s \sim p_s} \left[w(s) \| \mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^*(\mathbf{x}_s, s, t) \|_2^2 \right]. \tag{11.5.1}$$

$s \to t$ 的对角情形退为学习瞬时速度的流匹配：

$$\mathbb{E}_t \mathbb{E}_{\mathbf{x}_t \sim p_t} \left[w(t) \| \mathbf{h}_\theta(\mathbf{x}_t, t, t) - \mathbf{v}^*(\mathbf{x}_t, t) \|_2^2 \right]. \tag{11.5.2}$$

该形式与统一流映射目标等价联系见第 11.5.3 节。理想平均漂移通常无闭式，对 $(t-s)\mathbf{h}^* = \int_s^t \mathbf{v}^* du$ 沿轨迹关于起时 s 求导，得到 MF 恒等式：

$$\begin{aligned} \mathbf{h}^*(\mathbf{x}_s, s, t) &= \mathbf{v}^*(\mathbf{x}_s, s) - (s-t) \frac{d}{ds} \mathbf{h}^*(\mathbf{x}_s, s, t) \\ &= \mathbf{v}^*(\mathbf{x}_s, s) - (s-t) \left[(\partial_{\mathbf{x}} \mathbf{h}^*)(\mathbf{x}_s, s, t) \mathbf{v}^*(\mathbf{x}_s, s) + \partial_s \mathbf{h}^*(\mathbf{x}_s, s, t) \right]. \end{aligned} \tag{11.5.3}$$

链式法则使用 $d\mathbf{x}_s/ds = \mathbf{v}^*(\mathbf{x}_s, s)$。以停止梯度替代目标，实践训练为

$$\mathcal{L}_{\mathrm{MF}}(\theta) := \mathbb{E}_{t<s}\mathbb{E}_{\mathbf{x}_s\sim p_s}\left[w(s)\|\mathbf{h}_\theta(\mathbf{x}_s, s, t) - \mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s, s, t)\|_2^2\right], \tag{11.5.4}$$

其中

$$\mathbf{h}^{\mathrm{tgt}}_{\theta^-}(\mathbf{x}_s, s, t) := \mathbf{v}^*(\mathbf{x}_s, s) - (s-t)\underbrace{\left[(\partial_{\mathbf{x}}\mathbf{h}_{\theta^-})\mathbf{v}^*(\mathbf{x}_s, s) + \partial_s\mathbf{h}_{\theta^-}\right]}_{\mathrm{JVP}}.$$

理想速度不可闭式计算，可用预训练流匹配教师蒸馏，或由数据直接估计。两者都需求目标网络 JVP，源记号为 $[\partial_{\mathbf{x}}\mathbf{h}_{\theta^-}, \partial_s\mathbf{h}_{\theta^-}, \partial_t\mathbf{h}_{\theta^-}]^\top \cdot [\mathbf{v}^*, 1, 0]$。

- **蒸馏：** 使用流匹配骨架预训练 $\mathbf{v}_{\phi^\times} \approx \mathbf{v}^*$；
- **从头训练：** 用配对 $\mathbf{x}_0, \boldsymbol{\epsilon}$ 的条件速度 $\alpha'_s\mathbf{x}_0 + \sigma'_s\boldsymbol{\epsilon}$。给定 $\mathbf{x}_s$ 的条件平均恢复边缘瞬时漂移，单点为条件无偏估计。

译注： JVP 的行/列 Jacobian 约定应与式 (11.5.3) 的分量链式法则一致；向量时间分量为 $(1, 0)$，终止时间 t 固定，不包含 ∂_t 贡献。

11.5.2 Mean Flow 的采样

训练好后，$\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + (t-s)\mathbf{h}^*(\mathbf{x}_s, s, t) \approx \mathbf{x}_s + (t-s)\mathbf{h}_{\theta^\times}(\mathbf{x}_s, s, t)$。因此从 $\mathbf{x}_T \sim p_{\mathrm{prior}}$ 一步生成 $\mathbf{x}_0 \leftarrow \mathbf{x}_T - T\mathbf{h}_{\theta^\times}(\mathbf{x}_T, T, 0)$；或准备网格，像 CTM 一样顺序应用长跳。因学习一般映射，也可使用类似 CTM 的可控随机采样族；具体加噪系数须对应所选调度。

11.5.3 CTM 与 MF 的关系

它们是同一理想流映射的不同参数化，平方理想回归误差只相差已知时间权重（Hu et al., 2025）。

参数化联系。 同一流可写为

$$\begin{aligned}
\Psi_{s\to t}(\mathbf{x}_s) &= \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du \\
&= \frac{t}{s}\mathbf{x}_s + \frac{s-t}{s}\underbrace{\left[\mathbf{x}_s + \frac{s}{s-t}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du\right]}_{\approx \mathbf{g}_\theta} \\
&= \mathbf{x}_s + (t-s)\underbrace{\left[\frac{1}{t-s}\int_s^t \mathbf{v}^*(\mathbf{x}_u, u)du\right]}_{\approx \mathbf{h}_\theta}.
\end{aligned}$$

第二式突出 CTM 残差，第三式突出 MF 平均漂移。

训练损失联系。 令 $\mathbf{g}_\theta(\mathbf{x}_s,s,t):=\mathbf{x}_s-s\mathbf{h}_\theta(\mathbf{x}_s,s,t)$，以平方距离为例，代入统一目标：

$$\begin{aligned}
&d(G_\theta(\mathbf{x}_s,s,t),\Psi_{s\to t}(\mathbf{x}_s))\\
&=\|G_\theta(\mathbf{x}_s,s,t)-\Psi_{s\to t}(\mathbf{x}_s)\|^2\\
&=\left\|\left(\frac{t}{s}\mathbf{x}_s+\frac{s-t}{s}\mathbf{g}_\theta\right)-\left(\frac{t}{s}\mathbf{x}_s+\frac{s-t}{s}\left[\mathbf{x}_s+\frac{s}{s-t}\int_s^t\mathbf{v}^*(\mathbf{x}_u,u)du\right]\right)\right\|^2\\
&=\left(\frac{s-t}{s}\right)^2\left\|\mathbf{g}_\theta-\left(\mathbf{x}_s+\frac{s}{s-t}\int_s^t\mathbf{v}^*(\mathbf{x}_u,u)du\right)\right\|^2.
\end{aligned}\tag{11.5.5}$$

继续代入残差与平均漂移关系，

$$\begin{aligned}
&\left(\frac{s-t}{s}\right)^2\left\|(\mathbf{x}_s-s\mathbf{h}_\theta)-\left(\mathbf{x}_s+\frac{s}{s-t}\int_s^t\mathbf{v}^*(\mathbf{x}_u,u)du\right)\right\|^2\\
&=\left(\frac{s-t}{s}\right)^2\left\|(\mathbf{x}_s-s\mathbf{h}_\theta)-\left(\mathbf{x}_s+\frac{s}{s-t}\int_s^t\mathbf{v}^*(\mathbf{x}_u,u)du\right)\right\|^2\\
&=(s-t)^2\left\|\mathbf{h}_\theta(\mathbf{x}_s,s,t)-\frac{1}{t-s}\int_s^t\mathbf{v}^*(\mathbf{x}_u,u)du\right\|^2.
\end{aligned}\tag{11.5.6}$$

源文中间同一代入式重复一次，以上保留。由此

$$\frac{1}{s^2}\|\mathbf{g}_\theta-\mathbf{g}^*\|^2=\|\mathbf{h}_\theta-\mathbf{h}^*\|^2.$$

撇开具体学习算法，两理想损失具有同一数学形式，仅权重不同。取 $t=0$ 均恢复 CM 的任意时刻到干净端点设定。[17]

实际辅助损失。 CTM 联合一致性与局部扩散损失；MF 也控制 $s\neq t$ 与 $s=t$ 对比例，混合平均漂移目标 (11.5.4) 与对角流匹配 (11.5.2)。两参数化均可从固定回归目标的瞬时速度学习，平滑过渡到停止梯度伪回归的流映射学习。

两者均支持灵活推断。 二者显式近似时间间映射，也可兼容引导、经验 ODE 似然和高阶求解器，因为对角极限恢复瞬时漂移：$\mathbf{g}^*(\mathbf{x}_s,s,s)=\mathbf{x}_s-s\mathbf{v}^*(\mathbf{x}_s,s)$，$\mathbf{h}^*(\mathbf{x}_s,s,s)=\mathbf{v}^*(\mathbf{x}_s,s)$。专门的 $\Psi_{s\to 0}$ 模型不直接共有此性质。

结论。 理想层面，它们类似扩散模型不同参数化，编码同一流；满足残差关系时理想误差仅差时间缩放，但实际替代目标和优化不同。CTM 目标为直接作用于流映射的积分形式，训练中需 ODE 求解；MF 由微分恒等式构造可计算目标。源文将其类比 EBM 学习密度的 “积分” 与得分匹配学习导数的 “微分”，这属于结构类比，而非说所有密度都是某个此处未定义积分。

实际表现随权重、架构与优化而异。MF 目标依全导数/JVP，源文此处称 “有限差分”；按前文具体实现理解，不将 JVP 误写成必需数值差分。两者并非唯一可行参数化，其他流映射表示可能带来稳定高效独立生成原则，值得探索。

[17]译注：这里是满足给定参数化关系的理想平方回归误差恒等式，不等于 CTM 实际自蒸馏/感知/GAN 目标与 MF 停止梯度目标相同。

11.6 结束语

本章从慢迭代扩散采样走到从头学习的快少步生成。共同对象是理想流映射 $\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{x}_s + \int_s^t \mathbf{v}^*(\mathbf{x}_\tau,\tau)d\tau$，学习它，以一至数次长跳替代许多小数值更新。

KD、PD、CM、CTM 和 MF 虽以不同训练构造引入，均显式或隐式利用同一 ODE 解映射结构。流映射是微分方程和动力系统的经典对象，在连续介质和流体力学中有相关粒子与场描述。这里以半群、Lagrange 和 Euler 三种经典视角组织现代方法。[18]

半群视角：把旅程拆开。 有限步恒等式 $\Psi_{u\to t}(\Psi_{s\to u}(\mathbf{x}_s)) = \Psi_{s\to t}(\mathbf{x}_s)$ 如固定路线的分段旅行。KD 学完整 $T\to 0$，PD 把两相邻教师步压成一步，CM 学 $s\to 0$，CTM 推广一般 $s\to t$。

Lagrange 视角：移动终点。 固定起始状态时间 $(\mathbf{x}_s, s)$，改变终止时间 t，输出沿同一轨迹移动：

$$\partial_t \Psi_{s\to t}(\mathbf{x}_s) = \mathbf{v}^*(\Psi_{s\to t}(\mathbf{x}_s), t).$$

“Lagrange” 采用粒子观点，随终时变化追踪轨迹上的终点，其无穷小运动由当地速度给出。

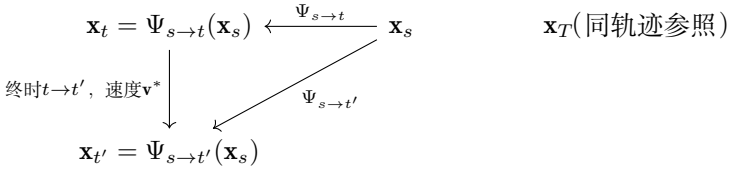


图 11.7: Lagrange 一致性：原图（a）终时 t 与（b）移动后 t' 对照。起点 $(\mathbf{x}_s, s)$ 固定，输出沿同一轨迹移动，瞬时变化等于当地 ODE 速度；图中两时刻速度分别为 $\mathbf{v}^*(\mathbf{x}_t, t)$、$\mathbf{v}^*(\mathbf{x}_{t'}, t')$。源图灰色轨迹的两面板改为可编辑映射及终点变化关系，$\mathbf{x}_T$ 保留作同轨迹参照。来源：改编自原引文键 `dieleman2026flowmaps`。

Euler 视角：移动起点。 固定终时 t，起点沿同一轨迹滑动，终点不变，$\frac{d}{ds}\Psi_{s\to t}(\mathbf{x}_s) = 0$。由 $d\mathbf{x}_s/ds = \mathbf{v}^*(\mathbf{x}_s, s)$，链式法则给出

$$\partial_s \Psi_{s\to t}(\mathbf{x}_s) + (\partial_{\mathbf{x}}\Psi_{s\to t})(\mathbf{x}_s)\mathbf{v}^*(\mathbf{x}_s, s) = 0.$$

“Euler” 借用经典场视角：固定终时，改变同轨迹起始状态时间，保持终点。CM 固定 $t = 0$，$\mathbf{f}^*(\mathbf{x}_s, s) = \Psi_{s\to 0}(\mathbf{x}_s)$，式 (11.3.1) 正是特殊流的起时一致性条件。

这也回顾 CTM 与 MF 联系：它们都近似同一积分，CTM 用位移式参数化表示终点，MF 以平均漂移表示同一终点。将 $\Psi_{s\to t} = \mathbf{x}_s + (t-s)\mathbf{h}^*$ 代入 Euler 起时恒等式，得到

$$\mathbf{h}^*(\mathbf{x}_s, s, t) = \mathbf{v}^*(\mathbf{x}_s, s) - (s-t)[\partial_s \mathbf{h}^*(\mathbf{x}_s, s, t) + (\partial_{\mathbf{x}}\mathbf{h}^*)(\mathbf{x}_s, s, t)\mathbf{v}^*(\mathbf{x}_s, s)],$$

即 MF 基本恒等式：长区间平均漂移等于起点瞬时漂移，再减去起点沿轨迹移动时平均漂移变化的修正。

[18] Boffi et al. (2024) 将 PD、CM、CTM、MF 已有结构思想汇总为共同语言，主要成分来自这些已有路线；本节叙述与插图也受原引文键 `dieleman2026flowmaps` 的阐释启发，源中损坏键照录。

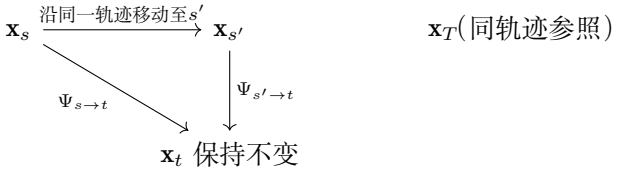


图 11.8: Euler 一致性：原图（a）起时 s 与（b）移动后 s' 对照。终时 t 固定，起点同属一条理想 PF-ODE 轨迹，故 $\Psi_{s\to t}(\mathbf{x}_s) = \Psi_{s'\to t}(\mathbf{x}_{s'})$；无穷小形式是沿轨迹起时全导数为零。两面板灰色轨迹改为可编辑共同终点图，参照 $\mathbf{x}_T$ 保留。来源：改编自原引文键 `dieleman2026flowmaps`。

三个视角的数学等价。 精确 ODE 流在标准存在、唯一和光滑性下，经每个状态时间对都有唯一轨迹。半群拆分路径，Lagrange 跟随终点，Euler 移动起点并固定终点，是同一流的等价描述（源引文键 `arnold1988geometrical`、`chorin1993mathematical`）。有限区间半群关系的两种无穷小极限，分别在终点或起点附近缩短一段。

终时极限：Lagrange 恒等式。 固定起点，$\Delta t > 0$ 时，$\Psi_{t\to t-\Delta t}(\Psi_{s\to t}(\mathbf{x}_s)) = \Psi_{s\to t-\Delta t}(\mathbf{x}_s)$。令 $\mathbf{x}_t := \Psi_{s\to t}(\mathbf{x}_s)$，短流展开给出

$$\begin{aligned}\Psi_{t\to t-\Delta t}(\mathbf{x}_t) &= \mathbf{x}_t - \Delta t\mathbf{v}^*(\mathbf{x}_t, t) + O((\Delta t)^2),\\ \frac{\Psi_{s\to t-\Delta t}(\mathbf{x}_s) - \Psi_{s\to t}(\mathbf{x}_s)}{-\Delta t} &= \mathbf{v}^*(\mathbf{x}_t, t) + O(\Delta t).\end{aligned}$$

取极限得到 $\partial_t\Psi_{s\to t}(\mathbf{x}_s) = \mathbf{v}^*(\Psi_{s\to t}(\mathbf{x}_s), t)$。

起时极限：Euler 恒等式。 固定终时 t，沿同轨迹把起点逆移 $\Delta s > 0$：

$$\mathbf{x}_{s-\Delta s} := \Psi_{s\to s-\Delta s}(\mathbf{x}_s) = \mathbf{x}_s - \Delta s\mathbf{v}^*(\mathbf{x}_s, s) + O((\Delta s)^2).$$

半群给出 $\Psi_{s-\Delta s\to t}(\mathbf{x}_{s-\Delta s}) = \Psi_{s\to t}(\mathbf{x}_s)$。同时对起始状态和时间展开，

$$\begin{aligned}\Psi_{s-\Delta s\to t}(\mathbf{x}_{s-\Delta s}) = \Psi_{s\to t}(\mathbf{x}_s) &- \Delta s(\partial_{\mathbf{x}}\Psi_{s\to t})(\mathbf{x}_s)\mathbf{v}^*(\mathbf{x}_s, s)\\ &- \Delta s\partial_s\Psi_{s\to t}(\mathbf{x}_s) + O((\Delta s)^2).\end{aligned}$$

比较后除以 $-\Delta s$，得到 $\partial_s\Psi_{s\to t} + (\partial_{\mathbf{x}}\Psi_{s\to t})\mathbf{v}^* = O(\Delta s)$，取极限为零。因此固定终时、沿同轨迹移动起点不改变终点。

从任一微分恒等式恢复映射。 反过来，任一微分恒等式加 $\Psi_{s\to s} = I$ 边界可恢复同一流。Lagrange 恒等式从起点演化终点；Euler 恒等式表明 $\Psi_{\tau\to t}(\mathbf{x}_\tau)$ 沿特征 $\mathbf{x}_\tau = \Psi_{s\to\tau}(\mathbf{x}_s)$ 保持常数，所以 $\Psi_{s\to t}(\mathbf{x}_s) = \Psi_{t\to t}(\mathbf{x}_t) = \mathbf{x}_t$。

理想层面等价，近似后却导向不同算法：须选择强制哪个恒等式、停止梯度放在哪里、如何抽样并为时间对赋权、如何参数化。

收束。 本章从学习局部速度转向学习 ODE 解映射的有限片段。传统扩散反复调用局部场、数值积分；流映射模型在训练时摊销部分积分，一至数次求值跨越长区间。

它直接通向快生成，却把困难从采样转移到学习：模型需近似更全局对象，效果依赖参数化、可计算目标、时间对抽样/权重及优化稳定。流映射学习并非新的动力学概念，而是围绕经典对象的现代学习策略；它保留扩散的轨迹基础，扩展高效生成设计空间。目标不再只是推断时更有效积分，而是直接学有用的有限时间转移。

尾声与展望

第十二章　统一原理与未来之路

> 抽象的目的不是含糊其辞，而是创造一个新的语义层次，使我们能够在其中做到绝对精确。
>
> *Edsger W. Dijkstra*

本书各章始终围绕同一件事：概率质量如何在预先规定的变换下移动，以及如何反转、近似或利用这种运动来生成数据。最后这一章退后一步，明确其中的结构统一性。我们首先重访支撑前述内容的变量变换原理（第 12.1 节），再解释如何借助 Markov 核和连续时间 Markov 链，把同一概率输运观点扩展到离散状态空间（第 12.2 节），最后思考更广阔的图景（第 12.3 节）。

学完本章后，你将能够：

- 解释概率输运为何是本书各生成建模框架的共同原理；
- 将连续空间中由连续性方程和 Fokker–Planck 方程描述的概率演化，与有限状态中的对应物——主方程——联系起来；
- 解释离散空间中的逆向建模如何变化：普通 Euclid 得分场和速度场被转移核、概率比和跳率取代；
- 比较连续与离散状态空间中的变分、得分/比值及流视角，辨认共同之处与变化之处。

阅读路线。　本章是尾声，而非介绍新方法的章节。请将它作为综合回顾：从连续状态空间走向离散状态空间时，关注哪些原理不变、哪些数学对象必须改变。

12.1　密度输运的骨架

本书沿着两条紧密相关的路线展开。第一条是扩散模型本身，包括变分、得分及流表述，它们从不同数学角度描述概率律如何演化，以及如何反转这种演化以生成样本。第二条是受扩散启发的快速生成器，尤其是流映射模型：它们建立在同一输运观点上，却旨在学习更直接、更高效的生成器。尽管形式不同，所有这些方法都根植于一个组织思想：生成建模从根本上说是输运概率质量的问题。我们从 Gaussian 噪声等简单参考分布出发，构造一个逐渐将其连接到复杂数据分布的过程。

这一观点有用，是因为它将注意力从单个模型家族移向更基本的问题：当样本受预先规定的动力学驱动时，概率律如何演化？回答这一问题的数学语言是变量变换公式及其连续时间推广。在此意义上，变量变换原理不只是技术工具，还是扩散模型及其所启发的快速生成器的概念骨架。

共同的三步结构。 从高层看，本书方法都遵循同一简单模式：

1. 定义一个将数据逐渐移向简单参考分布的正向过程；
2. 通过适当的概率律演化方程，理解概率律在该过程下如何变化；
3. 学习一个生成机制，通过反转、近似或以其他方式利用这一演化来产生样本。

不同表述之间变化的是正向过程的选择、概率律演化方程的数学形式，以及生成机制的参数化和训练方式。

变量变换的层级。 附录 B 系统建立了从确定性双射到随机微分方程的变量变换公式序列。这里值得再次回顾，因为它揭示同一输运原理的多种表现形式。

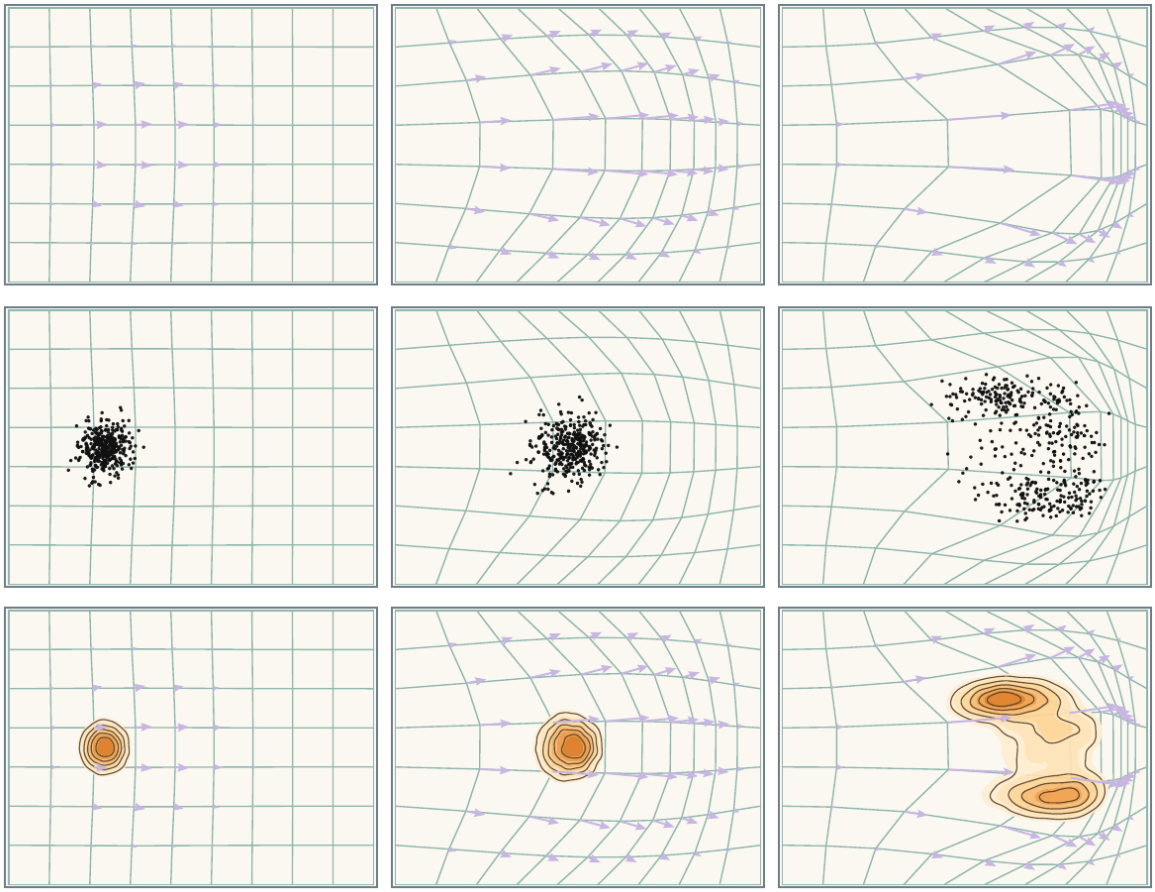


图 12.1: 向量场下的粒子与密度动力学示意。每行从左至右为相继时刻。(a) 上行：箭头是驱动粒子运动的速度，底层网格随之变形；(b) 中行：预定向量场产生流，将粒子云从初态输运出去；(c) 下行：粒子随场平流，密度等高线相应变形，显示流如何重塑分布。图像保留源 PDF 几何与粒子，不改变数据；英文分图说明移至本中文图注。来源：改编自 Lipman et al. (2024)。

1. **单个双射**。光滑可逆映射 $\Psi : \mathbb{R}^D \to \mathbb{R}^D$ 将密度 p_0 变为 p_1：

$$p_1(\mathbf{x}_1) = p_0\big(\Psi^{-1}(\mathbf{x}_1)\big)\,\big|\det \partial_{\mathbf{x}_1} \Psi^{-1}(\mathbf{x}_1)\big|\,.$$

Jacobian 行列式记录局部体积变化：映射拉伸空间时密度减小，压缩空间时密度增大。

2. **复合双射**。串联多个双射 $\mathbf{x}_k = \Psi_k(\mathbf{x}_{k-1})$，得到

$$\log p_L(\mathbf{x}_L) = \log p_0(\mathbf{x}_0) - \sum_{k=1}^{L} \log \left|\det \partial_{\mathbf{x}_{k-1}} \Psi_k(\mathbf{x}_{k-1})\right|.$$

这就是归一化流的基本原理。更重要的是，它已经体现核心信息：一旦规定粒子如何运动，密度演化便相应确定。

3. **连续时间确定性流（ODE）**。取无穷小步长极限，得到连续性方程

$$\frac{\partial p_t(\mathbf{x})}{\partial t} + \nabla \cdot \big(p_t(\mathbf{x})\mathbf{v}(\mathbf{x},t)\big) = 0,$$

对应粒子动力学 $d\mathbf{x}(t)/dt = \mathbf{v}(\mathbf{x}(t),t)$。这是质量守恒的连续时间表达：概率质量既不凭空产生，也不消失，只是在速度场作用下流过空间。

4. **连续时间随机流（SDE）**。加入 Brown 噪声后得到 Fokker–Planck 方程

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla \cdot \big(\mathbf{v}(\mathbf{x},t)p_t(\mathbf{x})\big) + \frac{1}{2}g^2(t)\Delta p_t(\mathbf{x}),$$

对应随机动力学

$$d\mathbf{x}(t) = \mathbf{v}(\mathbf{x}(t),t)dt + g(t)d\mathbf{w}(t).$$

第一项描述漂移引起的定向输运，第二项描述噪声引起的随机扩散。

这些公式并非互不相干。多层变量变换规则是反复确定性变换下输运的离散时间版本；其无穷小确定性极限给出连续性方程；再加入随机扰动，得到 Fokker–Planck 方程。每一级都扩展前一级，同时保留共同原理：概率质量守恒，而概率律随着底层动力学对样本的移动而调整。

由此，本书的主要表述更容易定位。变分方法借助时间网格上的去噪转移描述生成；得分方法采用随机动力学，学习支配逆时间 SDE 的得分场；流方法采用确定性输运，学习使边缘分布沿预定中间概率律族演化的速度场。快速生成器也基于这一骨架，只是寻求更直接利用已学输运以提高采样效率的方式。

核心认识是：扩散建模不宜只被理解为依附某种架构或噪声调度的单个算法，而是一条设计原理——指定正向输运过程，理解它诱导的概率律演化，再在这一结构上构造生成器。有了这一观点，许多看似不同的方法自然成为同一思想的变体。随之而来的问题是：这一原理能否超越连续状态空间？下一节给出肯定回答。

12.2 超越连续状态：离散空间上的概率演化

迄今本书各模型具有共同的结构假设：生成动力学作用的状态位于连续 Euclid 空间 $\mathbb{R}^D$。无论 $\mathbf{x}$ 的各分量是像素强度、音频采样还是连续潜变量，数学结构相同：粒子沿 ODE 或 SDE 控制的连续轨迹运动，概率密度则按连续性方程或 Fokker–Planck 方程演化。框架依赖 $\mathbb{R}^D$ 的微分结构：梯度与散度通过导数定义，确定性动力学可由向量场生成的可微轨迹描述。

此区分针对的是*建模状态*，而不是原始模态。离散观测也可先选择连续编码和读出。对原始符号 a，设编码为 $E(a) \in \mathbb{R}^d$，D 将编码映回符号，或更一般地映为分类分布：

$$\text{原始离散符号} a \xrightarrow{E} \text{连续编码} E(a) \in \mathbb{R}^d \xrightarrow{D} \text{离散读出}.$$

表示可以固定，例如独热、分类向量或单纯形取值编码（原引文键 richemond2022categorical）。在单射码本上，读出可为确定性并满足 $D(E(a)) = a$。表示也可学习，例如词元嵌入或自编码器潜变量（原引文键 li2022diffusionlm、dieleman2022continuous）；此时 D 是学习的读出，$D \circ E$ 不一定精确可逆。一旦确定表示，扩散就是连续状态扩散：在环境编码空间施加 Gaussian 噪声，或在受约束编码空间采用适应其几何的连续过程，都由前述连续理论处理。下面的有限状态路线有所不同：演化的状态本身始终离散。

本节研究互补情形：状态在正、逆过程的全过程中始终有限且离散。许多数据类型自然符合这一观点：文本是词表词元序列，分子图使用有限种原子和键，蛋白质是有限字母表上的序列。在有限状态空间中，从一个状态到另一个状态没有典范的无穷小位移，没有穿过词元取值的光滑轨迹，也没有关于状态本身的普通梯度。由此提出：

问题 12.2.1. *如果扩散确实关乎输运概率质量，那么当状态空间有限时，这一思想变成什么？*

结构骨架不变，数学对象改变。连续空间中的概率律由 ODE/SDE 动力学及连续性方程或 Fokker–Planck 方程支配；有限状态空间中的概率质量依据 Markov 转移核或跳率在状态之间移动，概率律按有限维守恒律演化，即主方程，也称 Kolmogorov 前向方程。从抽象层面看，两种情形遵循同一配方：

观察 12.2.1. *选择正向破坏过程，理解它诱导的概率路径，再学习逆向输运机制。*

在连续 Gaussian 扩散中，逆机制表现为 Gaussian 逆条件分布、得分或速度场；在有限状态空间中，它表现为逆转移概率、概率比或跳率。数学对象不同，但概念作用相同。

本章不将某个离散扩散算法视作定论，而是建立一张随文献变化仍保持稳定的路线图，按描述逆输运的对象——转移核、概率比或跳率——组织。依次讨论离散时间转移、连续时间极限、对应连续变分/得分比值/流的三种逆向视角，以及凸显连续与离散实质差别的比较。

12.2.1 离散时间转移

考虑 K 个离散类别上的正向过程，K 包括正向过程所需的掩码等特殊破坏词元。每个状态表示为独热列向量 $\mathbf{x} \in \{0,1\}^K$，恰有一个分量为 1，所有这类向量组成[1]

$$\mathcal{V} = \left\{ \mathbf{x} \in \{0,1\}^K : \sum_{i=1}^{K} x_i = 1 \right\} = \{\mathbf{e}_1, \dots, \mathbf{e}_K\}.$$

$\mathbf{e}_i$ 是第 i 个标准基向量，即类别 i 的独热编码。每个 $\mathbf{e}_i$ 可代表词元、离散潜编码、原子类型、键类型或氨基酸。

对文本或蛋白质等序列，一个样本有 N 个词元，每个词元取自大小为 K 的词表。完整状态空间为 $\mathcal{V}^N$，其大小随序列长度指数增长。许多离散扩散模型在正向过程中独立破坏各位置，因此单词元 Markov 过程是基本局部构件。先研究一个词元，便可在不过度增加记号的情况下揭示概率输运核心机制。对完整序列，同样公式适用于整个构型。若正向破坏逐位置独立，条件正向

[1]CTMC 及随机过程文献中的等价标准表述（原引文键 norris1998markov、kelly1979reversibility）用标量 $x \in \{1, \dots, K\}$ 表示状态，跳率记 $[\mathbf{Q}_t]_{ij}$，边缘记 $p_t(x)$。这里的独热表示在记号上等价，但更贴近离散扩散文献（原引文键 austin2021structured、sahoo2024simple；Lou et al., 2024），其中训练目标自然出现 $\langle \mathbf{x}_\phi, \mathbf{x} \rangle$ 和 $\mathbf{P}^\top \mathbf{x}$ 等运算。

核就按位置因子分解。[2]但学习的逆模型不必逐位置独立：Transformer 或图神经网络可观察整个受破坏对象，以全局上下文预测局部或全局逆转移。

在第 k 步，系统处于 K 个状态之一。处于 $\mathbf{e}_i$ 的标量概率记为

$$p_k(i) := \Pr(\mathbf{x}_k = \mathbf{e}_i), \qquad i = 1, \dots, K.$$

汇集为边缘概率向量

$$\mathbf{p}_k := (p_k(1), \dots, p_k(K))^\top = \mathbb{E}[\mathbf{x}_k] \in \Delta^{K-1} \subset \mathbb{R}^K, \qquad \sum_{i=1}^{K} p_k(i) = 1,$$

其中 $\Delta^{K-1} := \{\mathbf{p} \in \mathbb{R}^K : p_i \geq 0, \sum_i p_i = 1\}$ 为概率单纯形。等价地，$\Pr(\mathbf{x}_k = \mathbf{e}_i) = p_k(i)$，简记 $\mathbf{x}_k \sim \mathrm{Cat}(\mathbf{p}_k)$。因此 $\mathbf{p}_k$ 是离散随机状态 $\mathbf{x}_k$ 的完整概率律，而 $p_k(i)$ 是其第 i 个标量分量。连续时间采用相同约定：

$$p_t(i) := \Pr(\mathbf{x}_t = \mathbf{e}_i), \qquad \mathbf{p}_t := (p_t(1), \dots, p_t(K))^\top.$$

向量 $\mathbf{p}_t$ 是密度的离散对应物，说明总概率质量如何分配到 K 个状态。

沿用全书约定，粗体小写 $\mathbf{p}, \mathbf{x}$ 为向量，粗体大写 $\mathbf{P}, \mathbf{Q}$ 为矩阵，非粗体带指标量 $p_k(i)$、$[\mathbf{P}_k]_{ij}$、$[\mathbf{Q}_t]_{ij}$ 为标量分量。以随机变量为自变量的非粗体 p，如 $p(\mathbf{x}_{k-1} \mid \mathbf{x}_k)$，表示固定正向过程下的概率质量函数或转移核；$p_\phi$ 表示学习的逆模型。

系统如何移动？一步转移由矩阵 $\mathbf{P}_k \in \mathbb{R}^{K \times K}$ 指定，其分量

$$[\mathbf{P}_k]_{ij} = \Pr(\mathbf{x}_{k+1} = \mathbf{e}_j \mid \mathbf{x}_k = \mathbf{e}_i)$$

是当前位于 $\mathbf{e}_i$ 的系统一步后到达 $\mathbf{e}_j$ 的概率。于是完整矩阵具有结构

序列位置	1	2	3	4	$\cdots$	N
词元	the	cat	sat	on	$\cdots$	$\cdots$

词表指标	词元	选中 cat 时的独热编码
$\mathbf{e}_1$	dog	0
$\mathbf{e}_2$	cat	1
$\mathbf{e}_3$	ran	0
$\mathbf{e}_4$	the	0
$\mathbf{e}_5$	sat	0
$\mathbf{e}_6$	on	0
$\mathbf{e}_7$	mushroom	0

图 12.2: 从序列到独热状态。样本含 N 个词元，每个取自大小 K 的词表；本章聚焦一个词元在 K 个状态之间的演化。放大 cat 所在位置，取 $K = 7$，cat 对应 $\mathbf{e}_2 = (0, 1, 0, 0, 0, 0, 0)^\top \in \{0, 1\}^K$。状态空间是全部独热向量 $\mathcal{V}$；词表顺序任意，与词元在序列中的位置无关。原图的位置、词表、独热向量与两种维数用可编辑表格重建。来源：原作者以 AI 辅助编程制作。

[2]受破坏序列的边缘分布通常不必分解，因为干净数据分布可含有位置间依赖。

$$\mathbf{P}_k = \begin{pmatrix} [\mathbf{P}_k]_{11} & [\mathbf{P}_k]_{12} & \cdots & [\mathbf{P}_k]_{1K} \\ [\mathbf{P}_k]_{21} & [\mathbf{P}_k]_{22} & \cdots & [\mathbf{P}_k]_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ [\mathbf{P}_k]_{K1} & [\mathbf{P}_k]_{K2} & \cdots & [\mathbf{P}_k]_{KK} \end{pmatrix}, \quad \begin{array}{l}\text{行：当前状态}i,\\ \text{列：下一状态}j.\end{array}$$

沿第 i 行读取，即回答“给定系统当前处于 $\mathbf{e}_i$，各个可能下一状态的概率是什么?”每一行因此是目标状态上的概率分布：

$$[\mathbf{P}_k]_{ij} \geq 0 \quad (\forall i, j), \qquad \sum_{j=1}^{K} [\mathbf{P}_k]_{ij} = 1 \quad (\forall i).$$

非负性保证每个转移概率有效；行和约束保证从 $\mathbf{e}_i$ 流出的所有质量均被计入，系统总会落入某个状态。

分布如何演化。 给定转移矩阵，若系统初始分布为 $\mathbf{p}_k$，一步后是什么？对所有可能来源状态的流入质量求和：

$$p_{k+1}(j) = \sum_{i=1}^{K} p_k(i)[\mathbf{P}_k]_{ij}. \tag{12.2.1}$$

每项是 $\mathbf{e}_i$ 上的初始质量乘以从该处跳到 $\mathbf{e}_j$ 的概率。向量形式为

$$\mathbf{p}_{k+1} = \mathbf{P}_k^\top \mathbf{p}_k.$$

等价地，给定当前独热状态 $\mathbf{x}_k$，下一状态的条件分布是

$$\Pr(\mathbf{x}_{k+1} \mid \mathbf{x}_k) = \mathrm{Cat}(\mathbf{x}_{k+1}; \mathbf{P}_k^\top \mathbf{x}_k),$$

因为 $\mathbf{P}_k^\top \mathbf{e}_i$ 提取 $\mathbf{P}_k$ 第 i 行的转移概率。

按此规则演化的系统称为离散时间 Markov 链：给定当前状态 $\mathbf{x}_k$，$\mathbf{x}_{k+1}$ 的分布不依赖更早状态。这是连续空间概率律演化公式在有限状态中的对应物。连续情形中，双射 Ψ 重塑密度，而 Jacobian 行列式补偿局部体积变化；有限状态中没有体积元需要追踪，转移矩阵直接指定每个来源状态向各目标状态送去多少概率质量。行和约束保证总概率守恒，作用类似连续性方程的散度结构。

采用 $\mathbf{P}_0, \ldots, \mathbf{P}_{L-1}$ 重复多步，得到

$$\mathbf{p}_L = \mathbf{P}_{L-1}^\top \cdots \mathbf{P}_1^\top \mathbf{P}_0^\top \mathbf{p}_0.$$

这对应附录原式 (B.1.2) 的多层变量变换。连续确定性情形通过 Jacobian 行列式累积密度演化，这里则通过连续作用的 Markov 算子传播概率向量。底层思想相同：沿一系列规定的变换追踪概率质量。

反转单步。 有了正向机制，自然会问如何反转一次转移用于生成。若第 $k+1$ 步观测到 $\mathbf{e}_j$，上一步位于 $\mathbf{e}_i$ 的概率是什么？由 Bayes 公式，

$$\begin{aligned} \Pr(\mathbf{x}_k = \mathbf{e}_i \mid \mathbf{x}_{k+1} = \mathbf{e}_j) &= \frac{\Pr(\mathbf{x}_{k+1} = \mathbf{e}_j \mid \mathbf{x}_k = \mathbf{e}_i) \Pr(\mathbf{x}_k = \mathbf{e}_i)}{\Pr(\mathbf{x}_{k+1} = \mathbf{e}_j)} \\ &= [\mathbf{P}_k]_{ij} \frac{p_k(i)}{p_{k+1}(j)}, \qquad p_{k+1}(j) > 0. \end{aligned} \tag{12.2.2}$$

这是由正向转移 $\mathbf{P}_k$ 与当前边缘概率律共同确定的离散时间逆核。直观上，所有可能把质量送到 $\mathbf{e}_j$ 的方式中，来源 $\mathbf{e}_i$ 的贡献与原有质量 $p_k(i)$ 和跳转概率 $[\mathbf{P}_k]_{ij}$ 成正比。

- 分子 $[\mathbf{P}_k]_{ij}p_k(i)$ 是第 k 步位于 $\mathbf{e}_i$、随后跳到 $\mathbf{e}_j$ 的联合概率；
- 分母 $p_{k+1}(j)=\sum_{i'}p_k(i')[\mathbf{P}_k]_{i'j}$ 是从全部来源到达 $\mathbf{e}_j$ 的总概率，充当归一化常数，保证逆概率对 i 求和为 1。

关键是：逆核不是 $\mathbf{P}_k$ 的矩阵逆。Markov 转移可将多个状态的质量合并，作为线性映射不必可逆。概率意义上的反转是 Bayes 反演，不仅依赖正向转移矩阵，也依赖边缘分布 $\mathbf{p}_k$。生成建模困难恰在于此：$\mathbf{p}_k$ 由未知数据分布经正向过程推送得到，通常没有闭式表达。下面几种逆向建模视角，正是表达或学习实现这一 Bayes 反演所缺信息的不同方式。

12.2.2 连续时间极限：主方程

在连续空间的叙述中，将复合双射的步长缩至零便得到连续性方程（附录 B.1.2）。同一极限思想也适用于这里。时间步无穷小时，离散时间 Markov 链变为连续时间 Markov 链（CTMC），分布则按主方程演化。

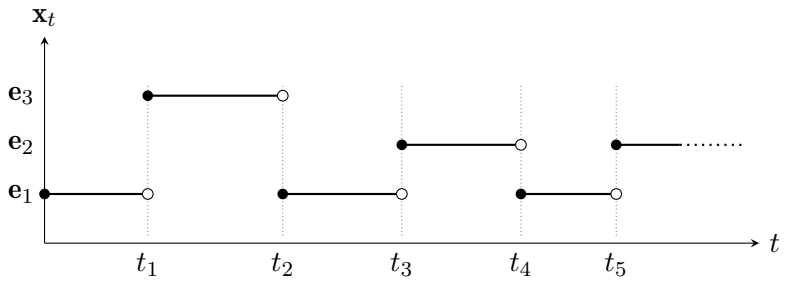


图 12.3: CTMC 样本路径示意，状态空间 $\mathcal{V}=\{\mathbf{e}_1,\mathbf{e}_2,\mathbf{e}_3\}$。路径分段常值：系统在 $\mathbf{e}_i$ 保持随机时长，再在 $t_1,t_2,\dots$ 瞬时跳到另一状态。实心点标记跳后状态，空心点标记跳前状态，体现右连续约定；点线表示展示窗口后的延续。跳时与目标由速率矩阵 $\mathbf{Q}_t$ 支配：从 $\mathbf{e}_i$ 向 $\mathbf{e}_j$（$j\neq i$）的瞬时跳率为 $[\mathbf{Q}_t]_{ij}$。示意路径以可编辑图重建，保留三状态、五次跳变与端点约定；非数据轨迹。源图正文称纵轴为 $\mathbf{e}_i$，原图注亦写 S_i，此处统一说明其为同一类别。来源：改编自原引文键 campbell2022continuous。

无穷小转移。 上一小节中，$\mathbf{P}_k$ 描述从 k 到 $k+1$ 的完整一步。现在将步长细分。设 $\mathbf{P}_{t,\Delta t}$ 为从时刻 t 起前进 Δt 的转移矩阵，$[\mathbf{P}_{t,\Delta t}]_{ij}$ 是在 $[t,t+\Delta t]$ 内从 $\mathbf{e}_i$ 到 $\mathbf{e}_j$ 的概率。Δt 很小时，大部分质量留在原处，只有小部分跳跃，因此矩阵接近恒等阵，可展开为

$$\mathbf{P}_{t,\Delta t}=\mathbf{I}+\mathbf{Q}_t\Delta t+O(\Delta t^2). \tag{12.2.3}$$

其中 $\mathbf{Q}_t\in\mathbb{R}^{K\times K}$ 为时刻 t 的速率矩阵，也称生成元。若 $\mathbf{Q}_t$ 对时间足够正则，局部余项可写作 $O(\Delta t^2)$。$\mathbf{Q}_t$ 的分量是瞬时速率，不是概率：

- $[\mathbf{Q}_t]_{ij}\geq 0$（$i\neq j$），表示从 $\mathbf{e}_i$ 跳到 $\mathbf{e}_j$ 的速率；乘以 Δt 给出短时间跳概率的首项。

- $[\mathbf{Q}_t]_{ii} = -\sum_{j\neq i}[\mathbf{Q}_t]_{ij}$。对角元非正，记录从 $\mathbf{e}_i$ 离开的总概率速率，保证每行和为零，这是速率层面的概率守恒。[3]

据此，从 $\mathbf{e}_i$ 跳到不同状态 $\mathbf{e}_j$ 的短时概率近似为 $[\mathbf{Q}_t]_{ij}\Delta t$，留在 $\mathbf{e}_i$ 的概率近似为 $1-\sum_{j\neq i}[\mathbf{Q}_t]_{ij}\Delta t$。

主方程。 将展开式 (12.2.3) 代入 $\mathbf{p}_{t+\Delta t} = \mathbf{P}_{t,\Delta t}^{\top}\mathbf{p}_t$，令 $\Delta t \to 0$，立即得到

$$\frac{d}{dt}\mathbf{p}_t = \mathbf{Q}_t^{\top}\mathbf{p}_t. \tag{12.2.4}$$

这是主方程，也称 CTMC 的 Kolmogorov 前向方程（原引文键 norris1998markov）。$\mathbf{p}_t$ 的第 j 项 $p_t(j)$ 是时刻 t 处于 $\mathbf{e}_j$ 的概率。分量形式为

$$\frac{d}{dt}p_t(j) = \underbrace{\sum_{i\neq j} p_t(i)[\mathbf{Q}_t]_{ij}}_{\text{流入：其他状态送来的质量}} - \underbrace{p_t(j)\sum_{\ell\neq j}[\mathbf{Q}_t]_{j\ell}}_{\text{流出：离开本状态的质量}}. \tag{12.2.5}$$

$p_t(j)$ 的变化率就是流入减去流出，即以微分方程表达概率守恒。

与连续性方程比较。 连续空间中，

$$\partial_t p_t(\mathbf{x}) + \nabla\cdot\big(p_t(\mathbf{x})\mathbf{v}(\mathbf{x},t)\big) = 0$$

说明密度变化由速度场产生的净概率通量驱动。主方程用有限状态语言表达同一件事：$p_t(j)$ 因 $\mathbf{Q}_t$ 支配的净概率通量而变化。速度场与速率矩阵在结构上扮演类似角色，均规定质量如何重新分配，并保证守恒。主要差别在几何上：$\mathbb{R}^D$ 中质量流经相邻位置，有限状态空间中质量沿转移图允许的边跳跃。

	掩码扩散（吸收）				均匀扩散（随机化）			
$t=0$ 数据	the	cat	sat	on	the	cat	sat	on
↓ 正向破坏	the	[M]	sat	on	the	dog	sat	on
	[M]	[M]	sat	[M]	run	dog	sat	by
$t=1$ 先验	[M]	[M]	[M]	[M]	run	fly	top	by
逆向生成	↑ 从全掩码先验开始				↑ 从均匀随机先验开始			

图 12.4: 掩码与均匀扩散的正向破坏和逆向生成。两例均有插值边缘 $\Pr(\mathbf{x}_t \mid \mathbf{x}_0) = \mathrm{Cat}(\mathbf{x}_t; \alpha_t\mathbf{x}_0 + (1-\alpha_t)\boldsymbol{\pi})$，先验 $\boldsymbol{\pi}$ 和衰减 α_t 由选定速率矩阵决定。掩码扩散把词元吸收到 $\mathbf{m} = \mathbf{e}_K$；均匀扩散反复随机化词元，极限先验为 $\boldsymbol{\pi}_{\text{unif}} = K^{-1}\mathbf{1}$。逆生成从相应简单参考分布，或其接近的有限时间近似出发，反转所选破坏过程。原词元、四时刻和双向含义以可编辑表格保留；[M] 为掩码，dog/run/by/fly/top 为随机替换，未改动源例中的 ran/run 不同拼写。来源：原作者以 AI 辅助编程制作。

[3] 由 $\mathbf{P}_{t,\Delta t}$ 每行和为 1 直接得到。代入 $\mathbf{P}_{t,\Delta t} = \mathbf{I} + \mathbf{Q}_t\Delta t + o(\Delta t)$，有 $1 + \Delta t\sum_j[\mathbf{Q}_t]_{ij} + o(\Delta t) = 1$，故 $\sum_j[\mathbf{Q}_t]_{ij} = 0$；分离对角元即得所述关系。

正向破坏。 与连续情形一样，需要一个逐渐破坏数据结构、将分布推向易采样简单参考分布的正向过程。这是连续扩散中选择 Gaussian 加噪过程的离散对应物。设计目标相同：破坏应渐进，能以解析或计算方式处理，并足够强，使数据结构到终止时刻 T 已大体消除。

速率矩阵有许多选择：均匀、吸收、近邻、基于图、按化学结构、识别语法，或其他适应数据领域的形式。下面两例并非穷尽分类，而是使机制清晰的典型情形。

掩码扩散（吸收）。 保留最后一个类别作为掩码，记 $\mathbf{m} := \mathbf{e}_K$。干净状态 $\mathbf{x}_0$ 取前 $K-1$ 类之一，故 $\langle \mathbf{x}_0, \mathbf{m} \rangle = 0$。定义所有普通状态以速率 $\beta(t)$ 跳入掩码，而掩码不再跳出：

$$[\mathbf{Q}_t]_{iK} = \beta(t), \quad [\mathbf{Q}_t]_{ii} = -\beta(t), \quad [\mathbf{Q}_t]_{ij} = 0 \quad (i < K,\ j \notin \{i, K\}),$$

并且 $[\mathbf{Q}_t]_{Kj} = 0$ 对所有 j 成立。每个词元独立以速率 $\beta(t)$ 被掩码替换，一旦掩码便保持不变。给定干净状态的正向边缘为

$$\Pr(\mathbf{x}_t \mid \mathbf{x}_0) = \mathrm{Cat}\big(\mathbf{x}_t; \alpha_t \mathbf{x}_0 + (1-\alpha_t)\mathbf{m}\big), \qquad \alpha_t = \exp\left(-\int_0^t \beta(s)ds\right).$$

时刻 t，词元以概率 α_t 保持干净值，以概率 $1-\alpha_t$ 被掩码。随着时间增加，质量越来越多地聚集在掩码状态。若 $\int_0^T \beta(s)ds$ 很大，则 α_T 很小，终端分布接近全掩码参考分布。

均匀扩散。 此过程逐渐随机化词元，而非将其擦除。一种方便的连续时间归一化是让词元以相同速率跳向其余 $K-1$ 个状态：

$$[\mathbf{Q}_t]_{ij} = \frac{\beta(t)}{K-1} \quad (i \neq j), \qquad [\mathbf{Q}_t]_{ii} = -\beta(t).$$

第一式给出到各替代状态的相同瞬时跳率，第二式说明离开 $\mathbf{e}_i$ 的总速率为 $\beta(t)$。正向边缘仍为插值形式

$$\Pr(\mathbf{x}_t \mid \mathbf{x}_0) = \mathrm{Cat}\big(\mathbf{x}_t; \alpha_t \mathbf{x}_0 + (1-\alpha_t)\boldsymbol{\pi}_{\mathrm{unif}}\big), \qquad \boldsymbol{\pi}_{\mathrm{unif}} = K^{-1}\mathbf{1} \in \mathbb{R}^K,$$

在上述速率归一化下，

$$\alpha_t = \exp\left(-\frac{K}{K-1}\int_0^t \beta(s)ds\right).$$

反复随机化逐渐洗去数据结构，将分布推向 $\mathcal{V}$ 上的均匀分布。

更一般的正向过程不必具有简单混合形式 $\Pr(\mathbf{x}_t \mid \mathbf{x}_0) = \mathrm{Cat}(\mathbf{x}_t; \alpha_t \mathbf{x}_0 + (1-\alpha_t)\boldsymbol{\pi})$。该形式便于直观理解，也出现在常见掩码与均匀构造中，但 Markov 概率律演化观点更一般：离散时间由转移矩阵控制，连续时间由速率矩阵经主方程控制。有结构的离散扩散可采用尊重编辑距离、图邻接、分子有效性、词表结构或其他领域知识的转移规则。共同原理始终是：正向 Markov 过程定义一条概率路径，生成则学习沿这条路径反向移动。

12.2.3 逆向建模的三种视角

确定正向过程及其概率律演化后，剩下的任务与连续情形相同：学习一个逆过程，使其边缘沿正向演化倒序返回，把简单参考样本变为数据。B 部按变分（第 2 章）、得分（第 3、4 章）和流（第 5 章）三种视角组织连续扩散。同一三分视角也适用于离散状态，但须强调：它们并非互斥学派或固定论文类别，而是识别“为了反转概率路径，必须学习什么未知对象”的三种方式。

变分视角：学习逆转移核。 连续情形的第 2.2 节将扩散视为层级潜变量模型。正向过程定义越来越噪的潜变量链，目标是学习逐步消除破坏的逆转移。真实逆核 $\Pr(\mathbf{x}_{k-1} \mid \mathbf{x}_k)$ 不可解，因为它依赖包含未知数据分布的 $\mathbf{x}_k$ 边缘律。DDPM 的关键洞见是给定干净样本 $\mathbf{x}_0$：正向后验 $\Pr(\mathbf{x}_{k-1} \mid \mathbf{x}_k, \mathbf{x}_0)$ 是闭式 Gaussian；原定理 2.2.1 说明，针对该条件后验训练，与针对不可解边缘逆核训练仅差不依赖学习模型的项。ELBO 分解为各噪声层级的 KL 项之和（原式 2.2.6），每项要求模型匹配可解正向后验。

离散情形逻辑相同。令 p 为先从数据分布抽取 $\mathbf{x}_0$、再应用固定正向链所得到的联合概率律，p_ϕ 为学习的逆模型。考虑受破坏的独热状态链

$$\mathbf{x}_0 \xrightarrow{\mathbf{P}_0} \mathbf{x}_1 \xrightarrow{\mathbf{P}_1} \cdots \xrightarrow{\mathbf{P}_{L-1}} \mathbf{x}_L,$$

其中 $\mathbf{x}_0$ 来自数据，$\mathbf{x}_L$ 接近全掩码或均匀等简单参考分布。转移现在是分类而非 Gaussian，但变分结构相同：

- 真实逆核 $p(\mathbf{x}_{k-1} \mid \mathbf{x}_k)$ 因依赖第 k 步边缘而不可解；
- 给定 $\mathbf{x}_0$ 后，Bayes 公式给出可解正向后验

  $$p(\mathbf{x}_{k-1} \mid \mathbf{x}_k, \mathbf{x}_0) = \frac{p(\mathbf{x}_k \mid \mathbf{x}_{k-1}) p(\mathbf{x}_{k-1} \mid \mathbf{x}_0)}{p(\mathbf{x}_k \mid \mathbf{x}_0)},$$

  右侧各因子均由正向过程决定；[4]
- 针对这些条件后验训练，与针对不可解边缘逆核训练具有相同最优逆核，差别仅在不依赖 p_ϕ 的项。

示意地，离散扩散 ELBO 含有如下去噪项：

$$\mathbb{E}_{p(\mathbf{x}_{0:L})} \left[D_{\mathrm{KL}}\big(p(\mathbf{x}_{k-1} \mid \mathbf{x}_k, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{k-1} \mid \mathbf{x}_k)\big) \right], \quad k = 1, \ldots, L.$$

具体模型的完整 ELBO 还包括终端先验项、靠近 $k = 0$ 的重构项等边界项。关键是，每一去噪项都要求逆核匹配由正向破坏决定的可解 Bayes 后验。

这里 $p_\phi(\mathbf{x}_{k-1} = \mathbf{e}_i \mid \mathbf{x}_k = \mathbf{e}_j)$ 是神经网络参数化的逆转移概率：给定第 k 步位于 $\mathbf{e}_j$，它给出上一时刻来自 $\mathbf{e}_i$ 的概率。每个固定 $\mathbf{e}_j$ 对应一个先前状态上的分类分布。

与连续 DDPM 相比，主要形式差异是这些 KL 是离散状态上的有限求和，而非 Gaussian 闭式公式。这反映 Gaussian 分布的特殊性质：同一变量的两个 Gaussian 密度之积正比于另一个 Gaussian。连续 DDPM 通过相乘 Gaussian 因子计算正向后验，结果仍为 Gaussian，KL 便化为仅含均值和协方差的简单代数表达（第 2.2 节）。离散情形 Bayes 公式给出分类分布，每项 KL 是状态求和。求和精确且概念简单，但对大词表或完整序列空间，可能需要结构、因子分解、子采样或专门参数化。

参数化还有一点实用区别。ELBO 要求逆核匹配 Bayes 后验，但不强制唯一网络参数化。一种常用方式是预测干净状态，即 $\mathbf{x}_0$ 预测。精确边缘逆核满足

$$p(\mathbf{x}_{k-1} \mid \mathbf{x}_k) = \sum_a p(\mathbf{x}_{k-1} \mid \mathbf{x}_k, \mathbf{x}_0 = \mathbf{e}_a) p(\mathbf{x}_0 = \mathbf{e}_a \mid \mathbf{x}_k),$$

[4]译注：该 Bayes 比值仅在 $p(\mathbf{x}_k \mid \mathbf{x}_0) > 0$ 的条件支撑上使用。若指定的干净类别与当前状态不相容，使分母为零，就不能直接用此比值定义后验。

其中对有效干净类别求和。这只是对未知干净状态边缘化。后验 $p(\mathbf{x}_0 \mid \mathbf{x}_k)$ 依赖数据分布，无闭式形式，故可让模型预测 $\widehat{p}_\phi(\mathbf{x}_0 \mid \mathbf{x}_k)$，并定义

$$p_\phi(\mathbf{x}_{k-1} \mid \mathbf{x}_k) := \sum_a p(\mathbf{x}_{k-1} \mid \mathbf{x}_k, \mathbf{x}_0 = \mathbf{e}_a)\widehat{p}_\phi(\mathbf{x}_0 = \mathbf{e}_a \mid \mathbf{x}_k).$$

若预测恰等于真实干净后验，此混合就恢复精确逆核。实践中，它将学习的逆转移与已知正向后验联系起来。[5]

干净状态参数化常见于多项分布扩散/D3PM 式离散时间扩散，却不是离散扩散的定义。

原文此处引文键为 `hoogeboom2021argmax`、`austin2021structured`。D3PM 本身指出也可直接预测逆 logit；后续模型采用适应正向过程的其他结构化参数化（原引文键 sahoo2024simple）。因此，干净状态预测是变分视角的一种重要参数化，并非唯一逆向建模方式。

得分/比值视角：学习局部概率比较。 连续得分视角从一个简单问题出发：给定受破坏样本 $\mathbf{x}_t \sim p_t$，反转扩散需要当前密度的什么局部信息？答案是出现在逆时间 SDE 与概率流 ODE 中的得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$。以神经网络学习得分便足以生成。

有限状态空间没有环境 Euclid 几何，没有普通无穷小位移，也没有关于状态的梯度。样本不通过 Euclid 小步移动，而是从一个状态跳到另一个状态。因此 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 没有直接字面对应物。但逆过程仍必须回答类似问题：若当前位于 $\mathbf{e}_j$，每个候选来源 $\mathbf{e}_i$ 相对于它有多大可能性？

推导逆跳率。 设正向 CTMC $\{\mathbf{x}_t\}_{0 \le t \le T}$ 的速率矩阵为 $\mathbf{Q}_t$，边缘为 $\mathbf{p}_t$。$[\mathbf{Q}_t]_{ij}$ 是从 $\mathbf{e}_i$ 到 $\mathbf{e}_j$ 的跳率。短时间内，$i \neq j$ 时事件 $\mathbf{x}_t = \mathbf{e}_i, \mathbf{x}_{t+\Delta t} = \mathbf{e}_j$ 的概率约为

$$p_t(i)[\mathbf{Q}_t]_{ij}\Delta t.$$

定义逆时间过程 $\bar{\mathbf{x}}_s := \mathbf{x}_{T-s}$，$0 \le s \le T$，边缘为 $\bar{\mathbf{p}}_s = \mathbf{p}_{T-s}$。若其速率矩阵为 $\bar{\mathbf{Q}}_s$，则从 $\mathbf{e}_j$ 到 $\mathbf{e}_i$ 的逆跳必须在相反时间次序下重现同一无穷小路径概率。令 $\Delta t \to 0$，得到非对角时间反转公式

$$[\bar{\mathbf{Q}}_s]_{ji} = [\mathbf{Q}_{T-s}]_{ij}\frac{p_{T-s}(i)}{p_{T-s}(j)}, \qquad i \neq j, \quad p_{T-s}(j) > 0. \tag{12.2.6}$$

等价地，若 t 是对应正向时间，$\widetilde{\mathbf{Q}}_t$ 表示按正向时间索引的逆生成元，则

$$[\widetilde{\mathbf{Q}}_t]_{ji} = [\mathbf{Q}_t]_{ij}\frac{p_t(i)}{p_t(j)}, \qquad i \neq j. \tag{12.2.7}$$

对角项由行和为零确定：

$$[\widetilde{\mathbf{Q}}_t]_{jj} = -\sum_{i \neq j}[\widetilde{\mathbf{Q}}_t]_{ji}.$$

这是标准 CTMC 时间反转公式（原引文键 kelly1979reversibility、anderson2012continuous），由原引文键 campbell2022continuous 用于离散扩散。它只在边缘概率为正的状态上理解；逆过程只反转正向过程允许的边上的概率通量：若 $[\mathbf{Q}_t]_{ij} = 0$，对应从 $\mathbf{e}_j$ 到 $\mathbf{e}_i$ 的逆率也为零。这不是平衡详细平衡假设，而是无穷小路径概率的局部时间反转恒等式。

[5]译注：对正概率的当前状态，真实干净后验只在与该状态相容的干净类别上赋予正权；零事件上的条件分布版本不影响真实混合。学习的 $\widehat{p}_\phi$ 则还须限制于相容支撑，或明确约定支撑外的条件核版本、采用保证相容的参数化。例如，纯掩码链中，一个未掩码词元不可能来自不同的未掩码干净词元；若模型仍给后者正权，未定义的条件核会实际影响混合。因此任意模型权重并不自动定义唯一、精确的逆核。

比值是得分的离散对应物。 式 (12.2.7) 中，正向速率已知，因为正向过程预先设计。未知量为 $p_t(i)/p_t(j)$，比较当前边缘中 $\mathbf{e}_i$ 与 $\mathbf{e}_j$ 的相对可能性。以内积表示，$p_t(i) = \langle \mathbf{p}_t, \mathbf{e}_i \rangle$，比值为 $\langle \mathbf{p}_t, \mathbf{e}_i \rangle / \langle \mathbf{p}_t, \mathbf{e}_j \rangle$。

为何这是得分的离散对应物？连续空间得分衡量对数密度随无穷小位移的变化；有限状态中的自然局部比较则跨越一条允许跳边。从 $\mathbf{e}_j$ 跳到 $\mathbf{e}_i$，对数概率变化为

$$\log p_t(i) - \log p_t(j) = \log \frac{p_t(i)}{p_t(j)},$$

是对数概率的有限差分，对应 $\mathbb{R}^D$ 中 $\log p_t$ 方向导数的作用。比较自然地局限于边：只需为正向跳结构连接的状态对提供比值。离散得分因此不是 $\mathbb{R}^D$ 上的 Euclid 向量场，而是允许转移上的局部概率比较集合。完整序列中，将 i, j 替换为完整构型即可；邻近构型常由 Hamming 或图转移结构规定。

网络学习什么。 连续得分模型训练 $\mathbf{s}_\phi(\mathbf{x}, t)$ 近似 $\nabla \log p_t(\mathbf{x})$，再将其代入逆时间 SDE 生成。离散情形在信息层面遵循同一逻辑：网络提供决定逆跳率所需的时变比值信息，随后利用学习的转移概率或速率模拟逆时间 Markov 链或 CTMC。

不同表述以不同方式表示这些信息。SEDD 等比值模型（Lou et al., 2024）用受得分匹配启发的损失估计 $p_t(i)/p_t(j)$ 或其对数形式。其他连续时间表述（原引文键 campbell2022continuous、sun2023scorebased）通过匹配条件转移概率等目标学习等价的逆向建模量。Meng et al. (2022) 的 concrete score（离散得分）形式化了将局部概率比较视为得分离散对应物的思想。参数化虽不同，原则共同：学习时间反转所需的局部概率比较，构造逆转移或逆率，再向后模拟。

流视角：学习离散输运场。 连续流视角直接学习速度场 $\mathbf{v}_t(\mathbf{x})$，使其 ODE 流将参考分布输运至数据。训练策略是流匹配：边缘速度不可解，给定数据或端点样本的条件速度 $\mathbf{v}_t(\mathbf{x} \mid \mathbf{x}_0)$ 却有闭式形式。两种目标满足

$$\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\mathbf{v}_t(\mathbf{x} \mid \mathbf{x}_0) \mid \mathbf{x}_t = \mathbf{x}],$$

即给定当前状态后对所有可能条件变量平均。显式求该平均需要连续边缘密度 $p_t(\mathbf{x})$；关键训练技巧（原第 5.3.2 节）是平方误差回归下条件目标与不可解边缘目标有相同总体最小化解。因此可从可解条件路径取样训练，避免显式计算边缘。

离散情形思路相同，速率矩阵替代速度场。离散状态不能沿词元空间中的连续轨迹移动，故速度场的角色由 Markov 生成元 $\mathbf{Q}_t$ 承担。$[\mathbf{Q}_t]_{ij}$ 指定从 $\mathbf{e}_i$ 到 $\mathbf{e}_j$ 的跳率，每单位时间实际送出的质量为通量

$$J_t(i, j) = p_t(i)[\mathbf{Q}_t]_{ij}.$$

在此意义上，速率矩阵是离散输运场，决定概率质量如何随时间重新分配。

须注意，概率路径 $\{\mathbf{p}_t\}_{t \in [0,T]}$ 不唯一决定速率矩阵。不同生成元可在主方程中产生相同的 $d\mathbf{p}_t/dt$，如同不同输运场有时可在不同几何约束下实现相同边缘演化。因此，离散流匹配不仅指定概率路径，还须指定沿路径分配条件跳率或概率流的规则。

和连续流匹配一样，边缘速率矩阵通常不可解，条件版本却常能显式构造。若给定干净数据状态和/或参考状态等端点，可指定条件概率路径，并推导其可解条件跳率；随后在适当的合宜

损失下，训练网络从受破坏样本预测相应转移或速率信息。边缘生成元仍由条件期望原理恢复：给定当前状态，对未知端点分布平均条件输运对象，但通过对条件目标做监督回归或分类来学习这一平均，而非显式求解。

- 连续流匹配以条件速度为目标，边缘速度作为流匹配损失下的最优预测器出现；
- 离散流匹配以条件转移或跳率为目标，边缘离散输运场通过类似条件期望机制出现。

两者都利用可解条件路径与采样的中间状态，避免处理不可解边缘律。原引文键 campbell2024 generative 与 gat2024discrete 以离散流模型或离散流匹配之名发展这一观点。更广泛地说，流视角所指的是学什么对象：离散状态空间上的输运场，可用转移、速率或概率流表达。

12.2.4 哪些相似，哪些有实质差别？

表 12.1 汇总连续与离散扩散的对应：每行是同一概念成分在两个环境中的不同实现。对应清楚，但离散理论并非简单把连续理论的梯度换成比值；还有若干更深的差别。

表 12.1: 概率输运的连续与离散视角。同一生成建模成分出现在连续与有限离散空间中，但对象不同：密度变为概率向量，ODE/SDE 动力学变为 Markov 链或 CTMC，逆建模通过转移核、得分/比值或离散输运场表达。

成分	连续（$\mathbf{x} \in \mathbb{R}^D$）	离散（$\mathbf{x} \in \mathcal{V} \subset \{0,1\}^K$）
概率律	密度 $p_t(\mathbf{x})$	概率向量 $\mathbf{p}_t \in \Delta^{K-1}$
样本动力学	ODE 或 SDE 轨迹	Markov 链或 CTMC 跳跃
概率律演化	连续性或 Fokker–Planck 方程	转移矩阵传播或主方程
输运对象	速度、漂移、扩散或得分场	转移核、速率矩阵、比值或概率流
参考律	简单分布，如 Gaussian	简单分布，如均匀或全掩码
	逆向建模的三种视角	
变分	Gaussian 或连续转移的 ELBO	分类转移的 ELBO
得分/比值	学习得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$	学习比值或对数比，如 $p_t(i)/p_t(j)$
流	学习速度场 $\mathbf{v}_t(\mathbf{x})$	学习转移、速率或概率流场

没有字面上的逆映射。 确定性连续归一化流的逆映射确实是正向映射的逆。离散 Markov 过程的正向核可合并多个状态质量，不必可逆，因此逆过程不由矩阵求逆得到，而是依赖当前边缘律的 Bayes 或时间反转构造。这就是逆转移概率包含 $p_k(i)/p_{k+1}(j)$、逆跳率包含 $p_t(i)/p_t(j)$ 等因子的原因。

几何与样本路径。 连续 Euclid 空间中，样本沿连续时间轨迹演化：ODE 解光滑，SDE 路径连续却通常处处不可微。[6]微分结构使速度场、得分与散度有意义。有限状态路径是纯跳路径，在随机保持时间内停于一个状态，再突然跳到另一个状态。平滑演化的不是样本路径本身，而是概率向量 $\mathbf{p}_t$：它依主方程在概率单纯形上连续演化。离散扩散因此仍可在概率演化层面统一描述，但样本层面由跳过程而非数据空间中的连续 ODE/SDE 路径支配。

[6]译注：此处沿源文作一般描述。ODE 解的光滑性依赖向量场正则性，典型非退化 Brown 驱动 SDE 路径才具有所述不可微性质；不把它理解为所有退化 SDE 的无条件断言。

正向破坏结构与逆向参数化。 离散扩散中，正向破坏通常是实质性建模选择。连续 Gaussian 扩散可改变 α_t, σ_t 调度，但正向核常仍为 Gaussian，主要改变破坏速率与尺度。离散情形中，转移规则本身可变：均匀破坏、掩码、近邻、图结构、领域专用转移，或更一般概率路径。D3PM（原引文键 austin2021structured）强调，正向过程可直接纳入领域归纳偏置，从而塑造逆向生成问题。

这也改变逆参数化的地位。Gaussian 情形的噪声、去噪数据、得分、速度等常见目标，由简单时变仿射变换联系；离散情形的逆转移概率、干净状态预测器、概率比与跳率，则经归一化、Bayes 公式和所选转移图联系。它们相关，却不是可简单互换的 Gaussian 式重参数化。因此，变分、得分/比值和流是逆问题的不同视角，而非同一代数目标的不同名称。

采样机制。 连续扩散通常在选定时间网格上数值积分 ODE/SDE。离散扩散生成则模拟逆 Markov 链或 CTMC：离散时间采样分类逆转移，连续时间则可能按学习的速率模拟跳跃，如事件驱动模拟或时间离散。因此，连续扩散中数值 ODE/SDE 求解器的作用，在离散情形由分类转移采样或跳过程模拟承担。

为何到此为止？ 本节旨在辨认跨状态空间保持不变的原理，而非发展离散扩散的完整理论。关键在结构上：连续空间的分布演化由变量变换原理及其微分形式——连续性方程、Fokker–Planck 方程——控制；离散空间由 Markov 算子与主方程承担对应作用。两者的建模逻辑一致：定义正向破坏过程，理解它如何输运分布，再学习逆输运机制用于生成。这一逻辑不依赖底层状态空间是连续还是离散。

改变的是实现这一方案的数学对象，而非方案本身。连续空间使用密度、梯度、速度场和 SDE/ODE 动力学；离散空间使用概率向量、转移核、跳率、比值及概率流。这些技术差别确实重要，导致不同的参数化、训练与采样问题，却不改变更深结论：概率输运观点不依附特定状态空间、架构或论文谱系，而是一条足以将连续与离散扩散纳入同一概念框架的普遍组织原理。

12.3 全书结束语

初看之下，扩散模型像是一堆缩写、参数化和算法变体；中心思想却很简单：通过规定概率律如何随时间演化来构造生成器。由此看，生成是正向过程与学习的逆过程对粒子云的受控输运。

这一观点贯穿全书，并以多种形式出现。连续状态空间中，变分、得分与流表述提供不同方式，描述和学习预定概率律演化的逆。受扩散启发的快速生成器——如流映射模型——也属于同一叙述：它们继续采用输运观点，追问能否更直接地表达、更高效地执行底层生成动力学。离散状态空间中，同一结构思想以 Markov 核、跳过程、比值和主方程的语言再次出现。

本书的主要信息并非让某一表述取代其他表述，而是把扩散理解为从预定正向过程构造生成器的一般原理（原引文键 lai2026unified）。不同状态空间自然导向不同逆表示。连续情形可用条件 Gaussian、得分、速度场或更直接的流映射；离散情形可用逆转移概率、干净状态预测器、概率比、跳率，或与底层 Markov 过程关联的概率流。要紧的是正向过程、诱导的概率律演化和学习的生成机制是否协调一致。

希望本书使这一结构变得清楚：正向过程诱导概率律演化，生成建模则学习如何反转、近似

或利用这种演化。具体方法会不断变化，但这一观点提供了稳定的理解方式，帮助我们判断它们为何奏效、如何关联，以及新发展可能来自何处。

重要的是不要停止提问。好奇心自有其存在的理由。 *Albert Einstein*

附录

附录 A　微分方程速成

微分方程（DE）是动力系统建模的基本工具，大体可分为常微分方程（ODE）、随机微分方程（SDE）与偏微分方程（PDE）。ODE 按精确规则描述系统状态随时间的变化，因而知道起点便能确定未来路径。SDE 在演化中加入随机性，模拟噪声或不确定性对系统行为的影响，使结果成为概率性的而非固定的。PDE 描述依赖时间、空间等多个变量的函数如何共同变化，刻画热扩散、波传播或随机系统中概率密度的时间演化（提前透露：Fokker–Planck 方程）等现象。这些微分方程构成理解系统在确定性和随机影响下如何随时间、空间演化的基本语言。

本附录给出微分方程的必要预备知识。

学完本章后，你将能够：

- 通过速度场、解轨迹以及存在唯一性的作用理解 ODE；
- 用积分因子揭示半线性 ODE 的线性结构，理解其对扩散 ODE 求解器的价值；
- 区分单步、多步与时间并行的数值视角，辨认 Euler、Runge–Kutta、Adams–Bashforth 和 Picard 迭代等代表方法；
- 理解 SDE 如何用 Brown 噪声扩展确定性动力学，其微分记号与 Itô 积分如何关联，以及 Euler–Maruyama 如何离散相应随机动力学。

阅读路线。　本附录提供全书所需的微分方程背景。请关注动力学、轨迹与数值近似之间的联系；后文扩散章节会将这些思想用于概率流 ODE 和随机扩散过程。

A.1　常微分方程基础

本节介绍 ODE 基本理论，着重讨论给定初始条件后解的唯一性，也介绍数值求解 ODE 的实用方法。

A.1.1　常微分方程的直观理解

这种确定性过程称为常微分方程。多变量情形考虑

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t), \tag{A.1.1}$$

其中 $\mathbf{x}(t) \in \mathbb{R}^D$ 是时刻 t 的系统状态，$\mathbf{v} : \mathbb{R}^D \times \mathbb{R} \to \mathbb{R}^D$ 是向量场，规定每个时空点的变化方向与大小。

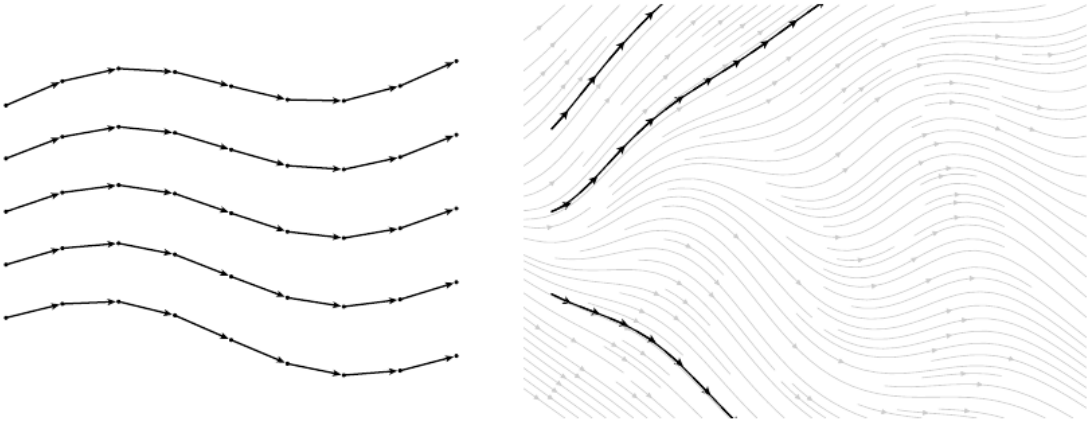


图 A.1: ODE 示意。速度场 $\mathbf{v}(\mathbf{x},t)$ 在每点赋予漂移向量，解轨迹 $\mathbf{x}(t)$ 的切向总与局部漂移相合。左图以点和箭头表示逐步求解器更新，近似连续路径；右图黑色精确轨迹与速度场一致流动。不指定初态时，有无穷多条瞬时变化符合该场的轨迹；固定 $\mathbf{x}(0)$ 后，在存在唯一性条件下确定唯一轨迹。原图几何保留，相关条件参见正文。来源：原作者。

求解 ODE 的高层直觉。 把 $\mathbf{v}(\mathbf{x},t)$ 想成随时间变化的箭头景观，告诉点 $\mathbf{x}$ 在时刻 t 应如何移动。求解微分方程，就是在场中追踪一条曲线，使其任意点的切向（瞬时速度）与 $\mathbf{v}(\mathbf{x}(t),t)$ 给出的向量对齐。

- 向量场视角：$\mathbf{v}(\mathbf{x},t)$ 给出运动或变化的局部“指令”；
- 轨迹视角：解 $\mathbf{x}(t)$ 是粒子每一瞬间都遵从场规则时走出的路径。

因此，求解 ODE 就像把粒子置于流场，观察它随时间走向何方。

A.1.2 常微分方程的存在与唯一性

求解 ODE 意味着找到处处沿向量场方向前行的路径，好比追踪粒子沿速度流场运动的轨迹。这引出关键问题：

问题 A.1.1. *选定起点后，真的存在一条遵从这些方向的路径吗？若存在，它唯一吗？粒子会不会突然改走另一条轨迹？*

答案决定能否从初态可靠预测系统行为。存在唯一性定理给出向量场的条件，保证每个给定初态恰好对应一条路径，使解的行为一致，构成 ODE 理论基石。

局部时间存在唯一性定理。 先陈述一个局部版本，保证给定初态在初始时刻邻域内有唯一解。

定理 A.1.1 (局部存在唯一性)**.** *设 $\mathbf{v}(\mathbf{x},t)$ 在区域 $\mathcal{D}\subseteq\mathbb{R}^D\times\mathbb{R}$ 内关于 $\mathbf{x},t$ 连续，并对状态满足 Lipschitz 条件*

$$\|\mathbf{v}(\mathbf{x}_1,t)-\mathbf{v}(\mathbf{x}_2,t)\|\le L\|\mathbf{x}_1-\mathbf{x}_2\| \qquad \forall(\mathbf{x}_1,t),(\mathbf{x}_2,t)\in\mathcal{D},$$

其中常数 $L > 0$。则每个初始条件 $\mathbf{x}(t_0) = \mathbf{x}_0$ 对式 (A.1.1) 都有定义在某区间 $[t_0 - \delta, t_0 + \delta]$ 上的唯一解。[1]

证明概要. 用 Picard–Lindelöf 迭代构造收敛于解的函数列：

$$\mathbf{x}_{n+1}(t) = \mathbf{x}_0 + \int_{t_0}^{t} \mathbf{v}(\mathbf{x}_n(s), s) ds.$$

从常值猜测 $\mathbf{x}_0(t) = \mathbf{x}_0$ 出发，反复用积分形式修正。Lipschitz 条件下，在足够小的时间区间应用压缩映射定理保证收敛。 □

证明核心是 Picard–Lindelöf 迭代，第 9.6 节也利用同一思想加速扩散采样。

全局时间存在唯一性。 局部定理只保证小时间区间的解；全局时间定理在额外正则条件下把结论扩展至整个 $[t_0, T]$。这一类的著名结果是 Carathéodory 定理：状态变量上的局部 Lipschitz 性与线性增长界是保证全局存在唯一性的两个关键假设。

1. 关于 $\mathbf{x}$ 的局部 Lipschitz 条件：存在 $[0, T]$ 上可积函数 $\mathrm{Lip}(t)$，使所有 $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^D$ 满足

$$\|\mathbf{v}(\mathbf{x}_1, t) - \mathbf{v}(\mathbf{x}_2, t)\| \le \mathrm{Lip}(t) \|\mathbf{x}_1 - \mathbf{x}_2\|.$$

2. 线性增长：存在 $[0, T]$ 上可积函数 $M(t)$，使所有 $\mathbf{x} \in \mathbb{R}^D$ 满足

$$\|\mathbf{v}(\mathbf{x}, t)\| \le M(t)(1 + \|\mathbf{x}\|).$$

完整假设、正式表述与证明见 Reid (1971)。[2]

注。 将这些定理用于扩散模型的概率流 ODE（原式 4.1.7）时，可能须对得分 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 加上 (i)、(ii) 等条件。不关注技术细节的读者可接受这些假设而不进一步论证。总之，在相关条件下，时变速度场定义的 ODE 一旦给定初值，粒子流轨迹便唯一确定。

唯一性意味着解不相交。 局部存在唯一性带来基本性质：不同初态出发的两条解轨迹不能相交。这体现确定性，每个状态沿唯一道路演化。形式化如下：

推论 A.1.1 (解不相交)**.** *考虑 ODE $d\mathbf{x}(t)/dt = \mathbf{v}(\mathbf{x}(t), t)$ 在 $t \in [0, T]$ 上的两个解 $\mathbf{x}_1, \mathbf{x}_2$。若满足上述唯一性条件且 $\mathbf{x}_1(0) \neq \mathbf{x}_2(0)$，则*

$$\mathbf{x}_1(t) \neq \mathbf{x}_2(t) \qquad \forall t \in [0, T].$$

[1] 译注：依源文陈述保留；标准局部定理还须初始点处于定义域内部或含有适当时空邻域，并取 δ 使轨迹留在该域。不能理解为任意集合 $\mathcal{D}$、域外初值或任意边界点均有双侧解。

[2] 译注：源文把第 (i) 项称为“局部”，但展示的不等式用同一个 $\mathrm{Lip}(t)$ 覆盖所有状态，实际上更强，为全局状态 Lipschitz 界。Carathéodory 理论还需要时间可测、状态连续等假设；这里保留源文作为概述，不将两条列表视为无其他条件的完整定理。

证明. 反设存在 $t^* \in (0,T]$，使 $\mathbf{x}_1(t^*) = \mathbf{x}_2(t^*)$。定义首次相遇时刻

$$t_0 := \inf\{t \in [0,T] : \mathbf{x}_1(t) = \mathbf{x}_2(t)\}.$$

初态不同且集合非空，由连续性得 $t_0 > 0$ 且 $\mathbf{x}_1(t_0) = \mathbf{x}_2(t_0)$。考虑以该共同状态为初值的问题

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}(\mathbf{x}(t), t), \qquad \mathbf{x}(t_0) = \mathbf{x}_1(t_0).$$

唯一性使两解在 $[t_0, T]$ 相同；向后应用唯一性又使其在 $[0, t_0]$ 相同。因此两解在整个 $[0,T]$ 一致，与初值不同矛盾。 □

保证解路径不相交，为第 10、11 章流映射模型提供隐含但关键的支撑。[3]

A.1.3 指数积分因子

一般时变速度场的 ODE 没有闭式解；某些特殊情形却可解析求解，或化为结构更好的表达。

说明性例子。 考虑标量线性 ODE $dx(t)/dt = L(t)x(t)$，其中 $L(t) \in \mathbb{R}$ 连续。任意 s, t 的已知闭式解为

$$x(t) = x(s) \exp\left(\int_s^t L(\tau) d\tau \right).$$

指数因子累积时变系数的作用，给出解的演化。这启发定义指数积分因子

$$E(s \to t) := \exp\left(\int_s^t L(\tau) d\tau \right), \tag{A.1.2}$$

尤其适用于同时含线性和非线性动力学的情形。

半线性 ODE 及其指数积分因子。 更广的半线性类将动力学分为状态的线性部分与非线性余项：

$$\frac{d\mathbf{x}(t)}{dt} = L(t)\mathbf{x}(t) + \mathbf{N}(\mathbf{x}(t), t), \tag{A.1.3}$$

其中 $\mathbf{x}(t) \in \mathbb{R}^D$，$L(t)$ 是连续标量函数，$\mathbf{N} : \mathbb{R}^D \times [0,T] \to \mathbb{R}^D$ 为非线性向量场。许多物理与工程系统自然有此结构，扩散概率流 ODE（原式 4.1.7）也不例外。识别该结构，可解析处理已知线性动力学，只对余项数值近似；这在第 9 章扩散 ODE 求解器中起核心作用。

步骤 1：用积分因子隔离非线性项。 移项得

$$\frac{d\mathbf{x}(t)}{dt} - L(t)\mathbf{x}(t) = \mathbf{N}(\mathbf{x}(t), t).$$

两侧乘逆积分因子 $E^{-1}(s \to t) = \exp(-\int_s^t L(\tau)d\tau)$，乘积法则给出

$$E^{-1}(s \to t) \left(\frac{d\mathbf{x}(t)}{dt} - L(t)\mathbf{x}(t) \right) = \frac{d}{dt} \left[E^{-1}(s \to t)\mathbf{x}(t) \right],$$

$$\frac{d}{dt} \left[E^{-1}(s \to t)\mathbf{x}(t) \right] = E^{-1}(s \to t)\mathbf{N}(\mathbf{x}(t), t).$$

该变换隔离非线性成分，使我们在变换坐标中聚焦非线性动力学。

[3]译注：这里严格指同一时刻状态不相同，即时空轨迹不交；时变场中，两条空间曲线在不同时刻经过同一空间点并未被排除。向后唯一性也须在相应区间具有所述条件。

步骤 2：沿时间积分。 从 s 积到 t：

$$\int_s^t \frac{d}{d\tau}\left[E^{-1}(s\to\tau)\mathbf{x}(\tau)\right]d\tau = \int_s^t E^{-1}(s\to\tau)\mathbf{N}(\mathbf{x}(\tau),\tau)d\tau.$$

左侧是变换变量在两端之差 $E^{-1}(s\to t)\mathbf{x}(t)-\mathbf{x}(s)$，故

$$E^{-1}(s\to t)\mathbf{x}(t) = \mathbf{x}(s) + \int_s^t E^{-1}(s\to\tau)\mathbf{N}(\mathbf{x}(\tau),\tau)d\tau.$$

步骤 3：解出状态。 乘以指数流 $E(s\to t)$，得到

$$\mathbf{x}(t) = \underbrace{E(s\to t)\mathbf{x}(s)}_{\text{线性部分}} + \underbrace{\int_s^t E(\tau\to t)\mathbf{N}(\mathbf{x}(\tau),\tau)d\tau}_{\text{非线性部分}}. \tag{A.1.4}$$

解自然分成线性与非线性部分。指数积分器精确处理线性部分，仅离散非线性残差，使步长主要受非线性动力学而非可能很大的线性系数限制（例如第 9.1 节指数 Euler 与普通 Euler 的比较）。[4]

A.1.4 常微分方程的数值求解器

考虑式 (A.1.1) 及给定初始条件。求解 ODE，就是寻找瞬时变化在每一时刻都与速度场一致的连续轨迹。等价地，解满足积分方程

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{v}(\mathbf{x}(\tau),\tau)d\tau. \tag{A.1.5}$$

若积分无闭式表达，就通过在有限个点计算速度场来数值近似轨迹。

从连续轨迹到数值更新。 求解器首先选择离散网格，并产生相应状态近似：

$$t_0, t_1, \ldots, t_M, \qquad \mathbf{x}_0, \mathbf{x}_1, \ldots, \mathbf{x}_M.$$

间隔 $h_i := t_{i+1} - t_i$ 为步长。较小步长一般提供更多局部轨迹信息，却需要更多函数求值。数值求解器的目的就是有效利用有限的 $\mathbf{v}$ 求值，用较少步数获得准确轨迹。不同方法主要区别在下一次更新所需信息来自何处，由此可作如下组织。

求解器的结构视角。 对本书相关方法，区分两类数值视角很有用：

- **时间步进方法**。从当前状态出发，逐个时间点推进轨迹，代表是 Euler、Runge–Kutta 和 Adams–Bashforth。进一步分为单步法与多步法：单步法根据当前状态及当前区间内部新增求值构造下一状态；多步法还复用此前已完成步骤的信息。
- **时间并行视角**。不严格逐一完成全部时间点，而是组织计算，使多个时刻的暂定状态可一起更新。Picard 迭代等不动点构造提供基本机制。

单步法不能与单次函数求值混淆。Euler 每步只求值一次，而 Runge–Kutta 可在中间阶段多次求值，仍属单步法。定义区别在于是否需要更早已完成步的信息。

[4]译注：该结论说明处理线性刚性项的结构优势，不是任意非线性系统、步长或求解器的无条件稳定性保证。L 为标量的假设不可直接换成不对易时变矩阵。

心中图景。 后文扩散采样所用数值 ODE 思想可组织为

$$\begin{gathered}\text{时间步进} \longrightarrow \begin{cases}\text{单步：Euler、Runge–Kutta,}\\ \text{多步：Adams–Bashforth,}\end{cases}\\ \text{时间并行} \longrightarrow \text{Picard 不动点迭代,}\\ \Downarrow\\ \text{同一数值思想可用于正向或反向时间。}\end{gathered} \tag{A.1.6}$$

这一区分对扩散采样尤其有用：Runge–Kutta 通过观察当前步内部获得更丰富信息，Adams–Bashforth 则向后查看已计算值。

正向和反向求解 ODE。 上述分类与积分方向无关。普通正向积分有 $t_{n+1} > t_n$、$h_n = t_{n+1} - t_n > 0$；扩散采样通常从含噪终态出发，采用递减网格 $t_{n+1} < t_n$、$h_n < 0$。把步长视为带符号量，同一数值公式适用于两个方向。因此，反时间积分 ODE 不需要新的一类求解器，Euler、Runge–Kutta、多步法等都可用于递减网格。须将这种简单反转与逆 SDE 区分：随机动力学的反转需要额外分析，下一节再讨论有关问题。

A.1.5 代表性数值求解器

上述分类说明求解器从何处取得下一步信息，下面用少数代表例具体说明。Euler 展示最简单单步更新；Runge–Kutta 展示当前步内的额外阶段；Adams–Bashforth 展示历史复用；Picard 展示时间并行背后的不动点视角。以下设 $t_{n+1} = t_n + h$，h 带符号：正向 $h > 0$，反向 $h < 0$。

Euler 方法。 最简单的单步法只用当前区间起点速度：

$$\mathbf{x}_{n+1} = \mathbf{x}_n + h\mathbf{v}(\mathbf{x}_n, t_n).$$

几何上，它观察当前方向，并沿该方向走完一步。在标准光滑假设下，局部截断误差为 $O(h^2)$，全局误差为 $O(h)$；其简单性使它成为有用的一阶基准，但若速度一步内显著变化，精度会下降。[5]

Runge–Kutta 方法。 Euler 只看区间起点，RK 在同一步内部生成额外阶段，对速度场求值以取得更多信息。它们是单步、多阶段方法：构造 $\mathbf{x}_{n+1}$ 的全部信息都由当前起点 $\mathbf{x}_n$ 产生，但每步可能包含多次求值。以下用两种二阶法说明。

显式中点法。 先用当前速度预测半步状态，再用该预测中点的速度走完整步：

$$\begin{aligned}\mathbf{x}_{\text{mid}} &= \mathbf{x}_n + \frac{h}{2}\mathbf{v}(\mathbf{x}_n, t_n),\\ \mathbf{x}_{n+1} &= \mathbf{x}_n + h\mathbf{v}\left(\mathbf{x}_{\text{mid}}, t_n + \frac{h}{2}\right).\end{aligned}$$

它先观察步内部，再决定如何完成更新，而不假定起点速度在整个区间都有代表性。

[5]译注：反向积分的误差阶按 $|h| \to 0$ 理解；全局阶还依赖稳定性和有限积分区间等标准条件。

Heun 方法（改进 Euler）。 另一种两阶段二阶 RK 法先用 Euler 预测终点，再平均起点和预测终点速度：

$$\begin{aligned}\mathbf{x}_{\text{pred}} &= \mathbf{x}_n + h\mathbf{v}(\mathbf{x}_n, t_n),\\ \mathbf{x}_{n+1} &= \mathbf{x}_n + \frac{h}{2}\left[\mathbf{v}(\mathbf{x}_n, t_n) + \mathbf{v}(\mathbf{x}_{\text{pred}}, t_n + h)\right].\end{aligned}$$

显式中点与 Heun 均用两阶段；在标准光滑假设下，局部误差 $O(h^3)$，全局误差 $O(h^2)$。差别只是如何采集、组合步内信息。高阶 RK 使用更多阶段扩展同一原则，此处省略标准公式。在扩散采样中，Karras et al. (2022) 直接采用 Heun 作为 ODE 求解器。

Adams–Bashforth 方法。 RK 在当前步内取新信息，多步法则向后看，复用更早已完成步骤的信息。例如均匀步长的二阶 AB2 为

$$\mathbf{x}_{n+1} = \mathbf{x}_n + h\left[\frac{3}{2}\mathbf{v}(\mathbf{x}_n, t_n) - \frac{1}{2}\mathbf{v}(\mathbf{x}_{n-1}, t_{n-1})\right].$$

第二份信息是前一步存储的速度，而非当前区间内部的新求值。在标准光滑假设及足够准确初始化下，AB2 局部误差 $O(h^3)$，全局误差 $O(h^2)$。第一步没有历史，须先用另一求解器初始化。该式假设均匀网格；非均匀网格的多步系数依赖邻近步长。历史复用原理会在第 9.3、9.5.4 节的扩散专用多步求解器中重现。

Picard 迭代。 上述方法通过局部时间步进近似轨迹；Picard 则借 ODE 积分形式，反复修正整条候选轨迹。从满足 $\mathbf{x}^{(0)}(0) = \mathbf{x}(0)$ 的初猜 $\mathbf{x}^{(0)}(t)$ 出发，定义

$$\mathbf{x}^{(k+1)}(t) = \mathbf{x}(0) + \int_0^t \mathbf{v}(\mathbf{x}^{(k)}(s), s)ds.$$

每轮沿上一候选轨迹评估速度，再构造新轨迹。不动点满足原 ODE 积分方程；在 Picard–Lindelöf 定理的标准条件下，迭代局部收敛于解。对后文重要的是计算层面：同一轮各时刻的速度只依赖上一候选轨迹，因此不同时间点可独立求值，为时间并行提供可能。第 9.6 节将再次采用这一视角。

A.2 随机微分方程基础

SDE 在 ODE 中纳入随机性，为受不确定性影响的系统提供数学框架。本节从 ODE 离散化出发，扩展到 SDE 离散化，再讨论一般 SDE 及 Itô 微积分和公式的背景。

A.2.1 从 ODE 到 SDE：直观引入

先考虑状态 $\mathbf{x}(t) \in \mathbb{R}^D$ 的确定性演化

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t), \qquad \mathbf{x}(0) = \mathbf{x}_0, \tag{A.2.1}$$

其中 $\mathbf{f}\colon \mathbb{R}^D \times [0, T] \to \mathbb{R}^D$ 是时变速度场。解是由初态完全确定的光滑轨迹 $t \mapsto \mathbf{x}(t)$。

离散化视角。 小时间步的 Euler 离散为 $\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t$。当 $\Delta t \to 0$，在 $\mathbf{f}$ 的标准正则条件下，近似趋于准确并收敛于 ODE 精确解。

引入随机性：从 ODE 到 SDE。 现实中无法完美掌握动力学；噪声、不确定性或未建模相互作用都可能影响演化。为此加入随机项：

$$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + \mathbf{f}(\mathbf{x}_t, t)\Delta t + g(t)\sqrt{\Delta t}\,\boldsymbol{\epsilon}_t, \tag{A.2.2}$$

其中 $g : [0, T] \to \mathbb{R}$ 是扩散系数（一般也可依赖状态，此处只依赖时间），$\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$ 是独立同分布 Gaussian 向量。该更新除确定性漂移外还含按 $\sqrt{\Delta t}$ 缩放的随机扰动；这种缩放保证 $\Delta t \to 0$ 时累积随机作用保持有限，并导向连续时间随机过程与 SDE 框架。

随机微分方程。 形式上，式 (A.2.2) 的极限定义

$$d\mathbf{x}(t) = \mathbf{f}(\mathbf{x}(t), t)dt + g(t)d\mathbf{w}(t). \tag{A.2.3}$$

$\mathbf{w}(t) \in \mathbb{R}^D$ 为 Wiener 过程，即标准 Brown 运动，具有：

- 初态 $\mathbf{w}(0) = \mathbf{0}$ 几乎必然成立；
- 独立增量：$0 \le s < t$ 时，$\mathbf{w}(t) - \mathbf{w}(s)$ 与过去独立；
- Gaussian 增量

$$\mathbf{w}(t) - \mathbf{w}(s) \sim \mathcal{N}(\mathbf{0}, (t-s)\mathbf{I}_D); \tag{A.2.4}$$

- 路径 $t \mapsto \mathbf{w}(t)$ 几乎必然连续却处处不可微。

常用记号 $d\mathbf{w}(t) := \mathbf{w}(t + dt) - \mathbf{w}(t)$ 表示无穷小 Wiener 增量。这是启发式记法，不能理解为 Riemann 或 Lebesgue 意义上的经典微分，因为 Brown 路径几乎必然处处不可微。它是 Gaussian 增量性质的简记：$d\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, dt\,\mathbf{I}_D)$，意指长度为 dt 的无穷小时段内，增量近似零均值、协方差 $dt\mathbf{I}_D$ 的 Gaussian 变量。

A.2.2 进一步解释 SDE 式

式 (A.2.3) 应按 Itô 意义理解为积分形式

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}(s), s)ds + \int_0^t g(s)d\mathbf{w}(s). \tag{A.2.5}$$

第一项积分为经典 Riemann 或 Lebesgue 积分，代表累积确定性漂移；第二项是对 Wiener 过程积分的 Itô 随机积分。这里不完整构造 Itô 积分，只给出直觉。

Itô 积分的直觉。 可将其理解为离散和的极限[6]

$$\sum_i g(t_i)\big(\mathbf{w}(t_{i+1}) - \mathbf{w}(t_i)\big),$$

被积函数在各子区间左端点 t_i 评估。分割越来越细时，和趋于 Itô 积分。[7]源文以左端点规则强调 Itô 积分与可采用中点等规则的经典积分的区别；Brown 路径连续但不可微，经典积分不能直接处理此类随机积分。Itô 积分处理这种不规则性，刻画随机涨落随时间的累积。[8]

微分记号的使用。 $d\mathbf{x}(t), dt, d\mathbf{w}(t)$ 在 SDE 式中是过程无穷小增量的形式记号，不应一律当作经典导数乘微分。它们虽有启发性，却广泛使用，因为能像 ODE 一样紧凑表达 SDE，并便于 Itô 微积分中的形式运算。附录 C 将解释其在扩散模型中的应用。

与 ODE 比较。 ODE $d\mathbf{x}/dt = \mathbf{f}(\mathbf{x}, t)$ 的积分形式

$$\mathbf{x}(t) = \mathbf{x}(0) + \int_0^t \mathbf{f}(\mathbf{x}(\tau), \tau) d\tau$$

由微积分基本定理保证，可从导数恢复可微函数。SDE 则没有这种直接照搬的对应，因为 Brown 运动不可微，随机积分不遵循经典链式法则；Itô 微积分以 Itô 引理等工具替代，分析和处理随机动力学。因此，紧凑直观的 SDE 微分记号，严格理解依赖 Itô 积分形式。

A.2.3 SDE 的一种数值求解器

与 ODE 一样，若系数满足适当正则条件，式 (A.2.3) 有唯一解：$\mathbf{f}(\cdot, t)$ 对状态 Lipschitz 且具有线性增长，$g(\cdot)$ 平方可积。[9][10] 一般 SDE 通常无闭式解，须数值求解。常用 Euler–Maruyama 将 ODE 的 Euler 法推广到随机情形，式 (A.2.2) 已经给出：在步长 Δt 上近似漂移，并用 $\sqrt{\Delta t}\boldsymbol{\epsilon}_t$、$\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 模拟 Brown 增量，乘以 $g(t)$ 模拟随机噪声。附录 C.1.5 将说明线性 SDE 具有闭式解。

---

[6]对平方可积的可预测被积过程，采用在 $L^2(dt \times \mathbb{P})$ 中逼近它的合适简单可预测过程，其随机积分在 L^2（均方）意义下收敛，因而也依概率收敛。对下方显示的左端点采样和，还须相应左端阶梯过程确实在该空间收敛；仅有适应性和平方可积性不足。L^2 观点自然连接到严格构造所用的 Itô 等距：$\mathbb{E}[\| \int_0^T \psi(t) d\mathbf{w}_t \|_2^2] = \mathbb{E}[\int_0^T \|\psi(t)\|_F^2 dt]$，其中 $\|\cdot\|_F$ 是 Frobenius 范数。附录 C.1.5 将陈述并应用它。

[7]译注：此处左端点阶梯近似需在 $L^2(dt \times \mathbb{P})$ 中逼近被积过程，例如在足够正则性下成立。对一般平方可积的可预测过程，Itô 积分由合适的简单可预测过程近似定义，不能仅由适应性与平方可积性推出任意点值采样和均方收敛。一个确定性反例是在 $[0,1]$ 上取 $g(t) = \mathbf{1}_{\mathbb{Q}}(t)$：它在 dt 几乎处处为零，积分为零；有理等分网格的所有左端点却取值 1，相应采样和恒为 $W_1 - W_0$，并不趋于零。

[8]译注：普通 Riemann 积分也可取左端点；关键差别是 Brown 积分器的非零二次变差，使不同采样规则一般给出不同随机积分。并非仅由“不可微”就能推出所有经典积分均不可用；这里保留原文的直观层次。

[9]这里指强解：在固定概率空间上，针对给定 Brown 运动 $\mathbf{w}(t)$，$\mathbf{x}(t)$ 满足积分形式 (A.2.5)。详细技术定义略去。

[10]译注：此处为源文条件概述；正式存在唯一性还需时间可测、初值适应性及相应一致/可积界等条件。

附录 B　密度演化：从变量变换到 Fokker–Planck

理解概率密度在变换下如何演化，是概率论与生成建模的基础。扩散模型尤其希望构造生成过程，使其诱导的密度路径反转预定正向过程。这种演化由连续性方程控制，随机情形则由 Fokker–Planck 方程控制。

这些名称或许陌生甚至令人畏惧，其实它们是基础微积分变量变换公式的连续时间对应物。第 B.1 节从确定性双射出发，逐级建立变量变换公式，最终到达随机微分方程，自然连接离散映射与连续流动力学。图 B.1 概述这一统一框架。第 B.2 节从物理直觉解释连续性方程，强调它与动力系统密度守恒的联系。

学完本章后，你将能够：

- 将变量变换公式与 ODE 的连续性方程、SDE 的 Fokker–Planck 方程联系起来；
- 将连续性方程理解为概率质量守恒，区分粒子运动与密度演化；
- 区分输运的 Lagrange 与 Euler 视角，理解为何单凭密度路径不必能唯一确定速度场；
- 理解 SDE 及其概率流 ODE 为何可共享同一边缘密度，却具有不同样本路径。

阅读路线。　关键原理是变量变换公式描述移动样本如何改变其分布。本附录将该思想从确定性映射推广至连续性和 Fokker–Planck 方程，并以 Wasserstein 梯度流作为分布层面训练的可选延伸。

B.1　变量变换公式：从确定性映射到随机流

通过类比经典微积分变量变换公式，我们消除连续性方程与 Fokker–Planck 方程的神秘感。先从熟悉的单变量情况出发，推广到多变量及概率密度，再到双射复合，其连续时间极限给出连续性方程；最后引入随机噪声，便自然扩展为 Fokker–Planck 方程。

B.1.1　确定性映射的变量变换公式

按确定性映射移动粒子，研究其概率律（密度）如何变化。关键是概率质量守恒，基础则是微积分与概率论的变量变换公式：它描述积分、从而描述密度，如何在光滑双射下变换。先讨论单次更新，再推广至连续多次变换。

变换	密度
$\mathbf{x}_0 \xrightarrow{\Phi} \mathbf{x}_1$	$p_0(\mathbf{x}_0) = p_1(\mathbf{x}_1)\lvert\det \partial_{\mathbf{x}_0}\Phi(\mathbf{x}_0)\rvert$
	↓ 多个双射
$\mathbf{x}_0 \xrightarrow{\Phi_1} \mathbf{x}_1 \to \cdots \xrightarrow{\Phi_L} \mathbf{x}_L$	$\log p_0(\mathbf{x}_0) = \log p_L(\mathbf{x}_L) + \sum_{k=0}^{L-1} \log\lvert\det \partial_{\mathbf{x}_k}\Phi_{k+1}\rvert$
	↓ 连续时间极限
$\frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t)$，定义流映射 $\Phi_{0\to t}$	$\partial_t p_t = -\nabla \cdot (\mathbf{f} p_t)$
	↓ 加入 Gaussian 噪声
$d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + g(t)d\mathbf{w}(t)$	$\partial_t p_t = -\nabla \cdot (\mathbf{f} p_t) + \frac{1}{2} g^2(t)\Delta p_t$

图 B.1: 统一变量变换公式。自上而下为单个双射、多双射复合、ODE 确定性连续流及其连续性方程、SDE 随机流及其 Fokker–Planck 方程。按原图四层关系与公式可编辑重建；Φ 与正文 Ψ 都是映射记号。来源：原作者。

单次更新。 把映射 $\Psi : \mathbb{R}^D \to \mathbb{R}^D$ 想成作用一个单位时间所产生的更新规则（源文类比向量场或力）。从初态 $\mathbf{x}_0$ 出发，下一状态为 $\mathbf{x}_1 = \Psi(\mathbf{x}_0)$。[1]

底层模式（密度）及其运动。 若初态服从密度 p_0，即 $\mathbf{x}_0 \sim p_0$，应用 Ψ 后状态 $\mathbf{x}_1$ 服从新密度 p_1。假设 Ψ 光滑且为双射，标准变量变换给出

$$p_1(\mathbf{x}_1) = p_0(\Psi^{-1}(\mathbf{x}_1)) \left|\det\left(\frac{\partial \Psi^{-1}}{\partial \mathbf{x}_1}\right)\right|. \tag{B.1.1}$$

$\partial_{\mathbf{x}}\Psi = \partial\Psi/\partial\mathbf{x}$ 为 Jacobian 矩阵。等价地，在原坐标中，

$$p_0(\mathbf{x}_0) = p_1(\Psi(\mathbf{x}_0))\lvert\det \partial_{\mathbf{x}}\Psi(\mathbf{x}_0)\rvert.$$

映射将 p_0 重塑为 p_1；因子 $\lvert\det \partial_{\mathbf{x}}\Psi\rvert$ 表示局部体积变化，概率质量守恒要求密度按其倒数补偿。若 Ψ 是可逆矩阵 $\mathbf{A}$ 定义的线性映射，则 $\mathbf{x}_1 = \mathbf{A}\mathbf{x}_0$，并有

$$p_1(\mathbf{x}_1) = p_0(\mathbf{A}^{-1}\mathbf{x}_1)\lvert\det \mathbf{A}^{-1}\rvert.$$

示意地，样本 $\mathbf{x}_0 \xrightarrow{\Psi} \mathbf{x}_1$，密度 $p_{\mathbf{x}_0}(\mathbf{x}_0) \xrightarrow{\Psi} p_{\mathbf{x}_1}(\mathbf{x}_1)$。

为何这就是变量变换公式？ 它直接来自熟悉的微积分规则。单变量 $y = \Psi(x)$ 光滑可逆时，

$$\int g(y)dy = \int g(\Psi(x))|\Psi'(x)|dx,$$

其中绝对导数补偿区间拉伸或压缩，使积分保持一致。多变量 $\mathbf{y} = \Psi(\mathbf{x})$ 时，

$$\int g(\mathbf{y})d\mathbf{y} = \int g(\Psi(\mathbf{x}))\lvert\det \partial_{\mathbf{x}}\Psi\rvert d\mathbf{x}, \qquad d\mathbf{y} = \lvert\det \partial_{\mathbf{x}}\Psi\rvert d\mathbf{x}.$$

于是密度公式为

$$\begin{aligned} p_{\mathbf{y}}(\mathbf{y}) &= \int_{\mathbb{R}^D} \delta(\mathbf{y} - \Psi(\mathbf{x}))p_{\mathbf{x}}(\mathbf{x})d\mathbf{x} \\ &= p_{\mathbf{x}}(\Psi^{-1}(\mathbf{y})) \left|\det\left(\frac{\partial \Psi^{-1}}{\partial \mathbf{y}}\right)\right|. \end{aligned}$$

[1]译注：这里 Ψ 是有限状态更新映射，不是直接把速度场数值当成流映射；速度场生成的流还须求解相应 ODE。

多个双射复合。 令 $\mathbf{x}_k = \Psi_k(\mathbf{x}_{k-1})$，$k = 1, \dots, L$，即

$$\mathbf{x}_0 \xrightarrow{\Psi_1} \mathbf{x}_1 \xrightarrow{\Psi_2} \cdots \xrightarrow{\Psi_L} \mathbf{x}_L.$$

各 $\Psi_k : \mathbb{R}^D \to \mathbb{R}^D$ 为光滑双射，$\mathbf{x}_0 \sim p_0$，则顺次诱导 $p_1, \dots, p_L$。每步质量守恒给出

$$p_k(\mathbf{x}_k) = p_{k-1}(\mathbf{x}_{k-1}) \left|\det \partial_{\mathbf{x}_{k-1}} \Psi_k(\mathbf{x}_{k-1})\right|^{-1}.$$

递推得

$$p_{\mathbf{x}_L}(\mathbf{x}_L) = p_{\mathbf{x}_0}(\mathbf{x}_0) \prod_{k=1}^{L} \left|\det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}}\right)\right|^{-1}. \tag{B.1.2}$$

等价的对数密度形式为

$$\log p_{\mathbf{x}_L}(\mathbf{x}_L) = \log p_{\mathbf{x}_0}(\mathbf{x}_0) - \sum_{k=1}^{L} \log \left|\det \left(\frac{\partial \Psi_k}{\partial \mathbf{x}_{k-1}}\right)\right|.$$

Jacobian 行列式刻画各次变换的体积伸缩，沿变换路径积累的局部体积变化决定复合映射后的最终密度。这是归一化流的核心原理（源定位第 5.1.2 节）。

B.1.2 连续时间极限：连续性方程

令粒子受时变速度 $\mathbf{f} : \mathbb{R}^D \times [0, T] \to \mathbb{R}^D$ 驱动，将 $\mathbf{x}_0 \sim p_0$ 经无穷多次小双射更新。每次长度 $\Delta t > 0$ 的更新为

$$\mathbf{x}_{t+\Delta t} = \Psi(\mathbf{x}_t) := \mathbf{x}_t + \Delta t \mathbf{f}(\mathbf{x}_t, t).$$

$\Delta t \to 0$ 时，更新复合趋向连续流

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}(t), t), \qquad \mathbf{x}(0) = \mathbf{x}_0 \sim p_0. \tag{B.1.3}$$

适当光滑条件下（见附录 A），每个初态有唯一解，定义流映射 $\Psi_{0\to t}$，将 $\mathbf{x}_0$ 送至时刻 t 的解：

$$\Psi_{0\to t}(\mathbf{x}_0) = \mathbf{x}_0 + \int_0^t \mathbf{f}(\mathbf{x}(\tau), \tau) d\tau.$$

整个分布也随之移动，p_0 被输运为 $\mathbf{x}(t)$ 的概率律 p_t，形式上记作推前 $p_t = (\Psi_{0\to t})_{\#} p_0$。流光滑可逆时，化为熟悉的变量变换：

$$\begin{aligned} p_t(\mathbf{x}) &= p_0(\Psi_{t\to 0}(\mathbf{x})) \left|\det \partial_{\mathbf{x}} \Psi_{t\to 0}(\mathbf{x})\right| \\ &= \int \delta(\mathbf{x} - \Psi_{0\to t}(\mathbf{x}_0)) p_0(\mathbf{x}_0) d\mathbf{x}_0. \end{aligned}$$

连续性方程：密度如何随时间运动。 不必在各时刻分别写密度公式，可用时空 PDE 描述其连续运动。概率质量守恒，速度场只在空间重新分配质量，因此

$$\frac{\partial}{\partial t} p_t(\mathbf{x}) + \nabla \cdot \big(p_t(\mathbf{x}) \mathbf{f}(\mathbf{x}, t)\big) = 0. \tag{B.1.4}$$

散度项衡量流如何局部膨胀或压缩密度，保证总概率保持为 1。[2]这一 PDE 是变量变换公式的连续时间对应物。

[2]译注：总质量守恒还使用无穷远衰减、无通量或其他合适边界条件；局部 PDE 本身不能在任意开边界上排除质量流失。

由变量变换推导连续性方程。 概念上可取式 (B.1.2) 的连续极限，这里采用单步公式的直接推导。Euler 更新 $\Psi(\mathbf{x}_t) = \mathbf{x}_t + \Delta t\mathbf{f}(\mathbf{x}_t, t)$ 的 Jacobian 展开为

$$\frac{\partial \Psi}{\partial \mathbf{x}_t} = \mathbf{I} + \Delta t \nabla_{\mathbf{x}} \mathbf{f}(\mathbf{x}_t, t) + O(\Delta t^2),$$
$$\det\left(\frac{\partial \Psi}{\partial \mathbf{x}_t}\right) = 1 + \Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + O(\Delta t^2).$$

这里使用 $\det(\mathbf{I} + \Delta t\mathbf{A}) = 1 + \Delta t \operatorname{Tr}\mathbf{A} + O(\Delta t^2)$ 及 $\nabla \cdot \mathbf{f} = \operatorname{Tr}(\nabla_{\mathbf{x}}\mathbf{f})$。变量变换给出

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) = \log p_t(\mathbf{x}_t) - \Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + O(\Delta t^2),$$

即

$$\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) = -\Delta t \nabla \cdot \mathbf{f}(\mathbf{x}_t, t) + O(\Delta t^2). \tag{B.1.5}$$

对左侧作多变量 Taylor 展开：

$$\begin{aligned}\log p_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - \log p_t(\mathbf{x}_t) &= \Delta t \partial_t \log p_t(\mathbf{x}_t) + (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + O(\Delta t^2) \\ &= \Delta t \partial_t \log p_t(\mathbf{x}_t) + \Delta t \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) + O(\Delta t^2).\end{aligned}$$

与式 (B.1.5) 比较，令 $\Delta t \to 0$，得

$$\partial_t \log p_t(\mathbf{x}_t) = -\nabla_{\mathbf{x}_t} \cdot \mathbf{f}(\mathbf{x}_t, t) - \mathbf{f}(\mathbf{x}_t, t)^\top \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

再由密度与对数密度关系和乘积法则，即得连续性方程。

确定性输运的 Lagrange 与 Euler 视角。 Lagrange 视角通过流映射追踪单个粒子；Euler 视角在固定空间位置描述速度 $\mathbf{f}(\mathbf{x}, t)$ 和密度 $p_t(\mathbf{x})$。在适当正则性下，两者一致：规定速度场产生粒子流，其推前密度满足连续性方程。

但有重要不对称性。速度场与初始密度固定后，流及密度演化都被确定；反过来，只给定密度路径通常不能唯一确定速度场或粒子流。

从速度到流与密度。 给定 $\mathbf{f}$，粒子 ODE $d\mathbf{x}/dt = \mathbf{f}(\mathbf{x}, t)$ 描述单粒子，密度 PDE $\partial_t p_t + \nabla \cdot (p_t \mathbf{f}_t) = 0$ 描述整个分布。按 ODE 移动粒子，自动产生满足 PDE 的密度。从 $\mathbf{x}(0) \sim p_0$ 出发，每条轨迹及流 $\Psi_{0\to t}$ 唯一确定，密度按连续性方程变化，粒子与密度动力学协调一致。

从密度路径到速度：不唯一性。 若只从 $t \mapsto p_t$ 出发（例如流匹配第 5.3.2 节），速度便不唯一。若 $\mathbf{w}_t$ 满足

$$\nabla_{\mathbf{x}} \cdot \big(p_t(\mathbf{x})\mathbf{w}_t(\mathbf{x})\big) = 0 \qquad （相对于 p_t \text{ 无净通量}），$$

则 $\mathbf{f}_t$ 与 $\mathbf{f}_t + \mathbf{w}_t$ 产生相同密度演化。一条密度路径可对应多种流；选择具体粒子流，相当于选择其中一种速度场。

并非任意给定 p_t 都能由粒子在某速度场中运动实现。连续性方程是检验密度路径能否“由流生成”的一致性条件。若存在速度场 $\mathbf{f}$，使其 ODE 经流映射恰好产生各 p_t，就称该路径可实

现（或由 $\mathbf{f}$ 生成），即 p_t 与 $\mathbf{f}$ 共同满足式 (B.1.4)。直观上，各密度快照能由运动粒子解释，而非任意分布序列。在适当正则条件下，p_t 正是 p_0 沿流的推前：

$$p_t = (\Psi_{0\to t})_{\#}p_0, \qquad p_t(\mathbf{x}) = p_0(\Psi_{t\to 0}(\mathbf{x}))\,|\det \partial_{\mathbf{x}}\Psi_{t\to 0}(\mathbf{x})| = \int \delta(\mathbf{x}-\Psi_{0\to t}(\mathbf{x}_0))p_0(\mathbf{x}_0)d\mathbf{x}_0.$$

（可选）条件化。 引入 $\mathbf{z}\sim\pi(\mathbf{z})$ 时，对每个固定 $\mathbf{z}$ 同样有

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_t(\mathbf{x}(t)\mid\mathbf{z}),$$
$$p_t(\cdot\mid\mathbf{z}) = (\Psi_{0\to t}(\cdot;\mathbf{z}))_{\#}p_0,$$
$$\partial_t p_t(\mathbf{x}\mid\mathbf{z}) + \nabla\cdot\big(p_t(\mathbf{x}\mid\mathbf{z})\mathbf{v}_t(\mathbf{x}\mid\mathbf{z})\big) = 0.$$

边缘密度为 $p_t(\mathbf{x}) = \int p_t(\mathbf{x}\mid\mathbf{z})\pi(\mathbf{z})d\mathbf{z}$。

B.1.3 随机过程：Fokker–Planck 方程

加入噪声后，动力学遵循式 (A.2.3) 的 SDE：$d\mathbf{x} = \mathbf{f}(\mathbf{x},t)dt + g(t)d\mathbf{w}(t)$。密度满足

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla\cdot\big(\mathbf{f}(\mathbf{x},t)p_t(\mathbf{x})\big) + \frac{1}{2}g^2(t)\Delta p_t(\mathbf{x}) = -\nabla\cdot\left[\left(\mathbf{f}(\mathbf{x},t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x})\right)p_t(\mathbf{x})\right].$$

$\Delta p_t = \nabla\cdot\nabla_{\mathbf{x}}p_t$ 为 Laplacian。第一行第一项描述确定性漂移输运，第二项描述噪声使密度散开，扩散项系数为 $g^2(t)/2$。[3]第二行将同一密度演化改写为速度

$$\mathbf{f}(\mathbf{x},t) - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$$

的连续性方程。因此，在相关正则性与初始条件下，由该速度驱动的确定性 ODE 具有与 SDE 相同的单时边缘 p_t，即全书使用的概率流 ODE。

注。 SDE 与 PF-ODE 一致的是密度路径，通常不是不同时刻样本的耦合。固定任意 t，两者分布相同，粒子“快照”的直方图相同；跨时间看，路径却不同。PF-ODE 给定 $\mathbf{x}_s$ 后，后续状态由 $\Psi_{s\to t}(\mathbf{x}_s)$ 决定；SDE 在 s 后继续注入新 Brown 噪声，即使给定 $\mathbf{x}_s$，后续状态仍随机。因此，转移分布、时间相关和路径事件可不同，尽管每个时刻边缘相同。PF-ODE 再现 SDE 边缘密度演化，而非完整随机路径律。图 4.5 作了说明。Fokker–Planck 推导较复杂，见附录 C.1.4。

B.2 连续性方程的直觉

本节从物理上解释连续性方程，强调其作为动力系统中概率密度守恒律的作用。

[3]译注：源文称噪声方差“正比于 $g^2/2$”；严格说 SDE 短时噪声协方差为 $g^2(t)dt\mathbf{I}$，1/2 来自 Fokker–Planck 二阶项约定。

B.2.1 连续性方程的物理解释

在三维空间取一个固定小矩形控制体，其一角位于 $\mathbf{x} = (x, y, z)$，边长为 $\Delta x, \Delta y, \Delta z$。设 $p(\mathbf{x}, t)$ 是某守恒量（如质量或概率）的密度。盒子足够小时，其中总量约为 $p(\mathbf{x}, t)\Delta x\Delta y\Delta z$。

总量如何改变？ 变化只能来自穿过盒子边界的通量。令 $\mathbf{j}(\mathbf{x}, t)$ 为通量向量，表示单位时间流过单位面积的量。

x 方向的通量。 左面 x 的流入约为 $j_x(x, y, z, t)\Delta y\Delta z$，右面 $x + \Delta x$ 的流出约为 $j_x(x + \Delta x, y, z, t)\Delta y\Delta z$。故净流入为

$$[j_x(x, y, z, t) - j_x(x + \Delta x, y, z, t)]\Delta y\Delta z.$$

全部方向的净通量。 y, z 方向对应项为

$$[j_y(x, y, z, t) - j_y(x, y + \Delta y, z, t)]\Delta x\Delta z,$$
$$[j_z(x, y, z, t) - j_z(x, y, z + \Delta z, t)]\Delta x\Delta y.$$

相加并作小盒展开，总净流入为 $-\nabla \cdot \mathbf{j}(\mathbf{x}, t)\Delta x\Delta y\Delta z$，等价的净流出为正号表达。盒内总量变化率约为 $\partial_t p(\mathbf{x}, t)\Delta x\Delta y\Delta z$。

守恒原理。 若该量守恒，变化率等于净流出的负值：

$$\partial_t p(\mathbf{x}, t)\Delta x\Delta y\Delta z = -\nabla \cdot \mathbf{j}(\mathbf{x}, t)\Delta x\Delta y\Delta z.$$

约去体积并取小盒极限，得到局部连续性方程

$$\partial_t p + \nabla \cdot \mathbf{j} = 0.$$

若散度为正，流出多于流入，盒内密度减小；散度为负，流入多于流出，密度增加。

B.2.2 从守恒律推导连续性方程

小盒给出局部直觉，现对任意控制体写出不依赖坐标的守恒原则。设 $p(\mathbf{x}, t)$ 是质量、电荷等守恒量密度，$\mathbf{x} \in \mathbb{R}^D$、$t \in [0, T]$，速度场为 $\mathbf{v}(\mathbf{x}, t)$。若该量随速度为 $\mathbf{v}$ 的粒子输运，则通量 $\mathbf{j} = p\mathbf{v}$。

步骤 1：控制体内的变化率。 取任意控制体 $V \subset \mathbb{R}^D$，边界为 ∂V。总量为 $\int_V p(\mathbf{x}, t)dV$，积累率为 $\partial_t \int_V p(\mathbf{x}, t)dV$。

步骤 2：穿过边界的净通量。 设外法向为 $\mathbf{n}$，净流出为

$$\int_{\partial V} p(\mathbf{x}, t)\mathbf{v}(\mathbf{x}, t) \cdot \mathbf{n}\, dS.$$

步骤 3：守恒。 积累率等于净流出的负值：

$$\frac{\partial}{\partial t}\int_V p\,dV + \int_{\partial V} p\mathbf{v}\cdot\mathbf{n}\,dS = 0.$$

步骤 4：散度定理。 将面积分化为体积分：

$$\begin{aligned}\int_{\partial V} p\mathbf{v}\cdot\mathbf{n}\,dS &= \int_V \nabla\cdot(p\mathbf{v})dV,\\ \frac{\partial}{\partial t}\int_V p\,dV + \int_V \nabla\cdot(p\mathbf{v})dV &= 0,\\ \int_V \left(\frac{\partial p}{\partial t} + \nabla\cdot(p\mathbf{v})\right)dV &= 0.\end{aligned}$$

控制体任意，在相应光滑条件下被积函数逐点为零：$\partial_t p + \nabla\cdot(p\mathbf{v}) = 0$，亦即 $\partial_t p + \nabla\cdot\mathbf{j} = 0$。

粒子层面的直觉。 展开散度，得 $\partial_t p + \mathbf{v}\cdot\nabla p + p\nabla\cdot\mathbf{v} = 0$。前两项是沿运动粒子的密度全变化率：

$$\begin{aligned}\frac{d}{dt}p(\mathbf{x}_t,t) &= \partial_t p(\mathbf{x}_t,t) + \mathbf{v}(\mathbf{x}_t,t)\cdot\nabla p(\mathbf{x}_t,t),\\ \frac{d}{dt}p(\mathbf{x}_t,t) &= -p(\mathbf{x}_t,t)\nabla\cdot\mathbf{v}(\mathbf{x}_t,t).\end{aligned}$$

邻近粒子散开时密度降低，聚拢时密度增加。速度场告诉我们单个粒子如何移动，连续性方程则告诉我们整个密度如何演化。

B.3 （可选）以 Wasserstein 梯度流理解分布层面的训练

现在从扩散特定动力学后退一步，以更广的分布视角看深度生成建模。连续性方程描述粒子运动引起的概率分布移动，同一语言也可解释训练：算法更新模型参数，更新后的生成器移动生成粒子，粒子移动进而改变诱导分布 p_ϕ。

因此可按模型分布 p_ϕ 如何被推向数据分布 p_{data} 组织不同方法。Wasserstein 梯度流给出一种清楚描述：把训练视为分布空间中理想化的概率质量流，再用有限维神经网络更新近似它。

生成器 G_ϕ 同时定义函数与分布。若 $\mathbf{z}\sim p_{\text{prior}}$、$\mathbf{x} = G_\phi(\mathbf{z})$，则生成分布为推前 $p_\phi := (G_\phi)_{\#}p_{\text{prior}}$。最终关心的是它如何接近数据分布，由此提出：

问题 B.3.1. 能否先描述把模型分布移向数据分布的理想方式，再更新神经网络参数，使生成器近似实现这种移动？

本可选节用 τ 表示训练时间，即离散训练迭代指标的理想连续版本，不能与扩散/加噪时间混淆。ϕ_τ 为训练时刻参数，p_{ϕ_τ} 为对应模型分布。

通过移动粒子移动模型分布。 先描述理想分布演化，再考虑有限维参数化。若当前模型粒子按训练时间速度 $\mathbf{w}_\tau$ 移动，

$$\frac{d\mathbf{x}_\tau}{d\tau} = \mathbf{w}_\tau(\mathbf{x}_\tau), \qquad \mathbf{x}_\tau\sim p_{\phi_\tau},$$

则分布满足

$$\partial_\tau p_{\phi_\tau}(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot \big(p_{\phi_\tau}(\mathbf{x})\mathbf{w}_\tau(\mathbf{x})\big) = 0.$$

$\mathbf{w}_\tau$ 描述每个生成粒子运动，连续性方程描述整个生成分布运动。[4]

选择速度：分布空间中的梯度下降。 令 $D(p_{\phi_\tau}, p_{\text{data}})$ 衡量当前模型与数据的差异。Wasserstein 梯度流（原引文键 jordan1998variational、ambrosio2005gradient）在移动概率质量的几何下选择最直接降低差异的粒子速度。

先问当前分布发生无穷小扰动时差异如何变化。把 $D(p, p_{\text{data}})$ 视为整体分布能量，其一阶变分给出逐点能量势，说明哪些区域对当前分布代价高、哪些区域有利。对小扰动 $p+\epsilon h$，$\epsilon > 0$、$\int h(\mathbf{x})d\mathbf{x} = 0$，定义

$$D(p + \epsilon h, p_{\text{data}}) = D(p, p_{\text{data}}) + \epsilon \int \frac{\delta D}{\delta p}(p, p_{\text{data}})(\mathbf{x})h(\mathbf{x})d\mathbf{x} + o(\epsilon).$$

p 只是分布自变量；求变分后在当前 $p = p_{\phi_\tau}$ 取值，定义逐点能量势

$$E_\tau(\mathbf{x}) := \frac{\delta D}{\delta p}(p_{\phi_\tau}, p_{\text{data}})(\mathbf{x}).$$

若 E_τ 大，在该处放更多质量就增加差异；若小，向该处移动质量有利。因此速度沿势能下坡：

$$\mathbf{w}_\tau(\mathbf{x}) = -\nabla_{\mathbf{x}} E_\tau(\mathbf{x}).$$

如此选择，

$$\frac{d}{d\tau} D(p_{\phi_\tau}, p_{\text{data}}) = -\int p_{\phi_\tau}(\mathbf{x}) \|\nabla_{\mathbf{x}} E_\tau(\mathbf{x})\|_2^2 d\mathbf{x} \le 0.$$

Wasserstein 梯度流因此是在概率分布 2-Wasserstein 几何中的梯度下降。[5][6]整体差异给出全分布能量，第一变分 E_τ 给出粒子所见局部景观，$-\nabla E_\tau$ 给出降低差异的理想速度。

用神经网络实现分布速度。 上述速度说明粒子应该怎样移动，但网络不能独立移动每个粒子，只能通过共享参数更新移动它们。在训练时刻 τ，取

$$\mathbf{x}_i = G_{\phi_\tau}(\mathbf{z}_i), \quad \mathbf{z}_i \sim p_{\text{prior}}, \quad i = 1, \dots, N.$$

小 Wasserstein 步把粒子移为 $\widetilde{\mathbf{x}}_i = \mathbf{x}_i + \eta \mathbf{w}_\tau(\mathbf{x}_i)$，$\eta > 0$。随后更新网络以匹配这些移动后的粒子：

$$\phi_{\tau+\eta} \approx \arg\min_{\phi} \frac{1}{N} \sum_{i=1}^{N} \big\| G_\phi(\mathbf{z}_i) - \text{sg}\big(\mathbf{x}_i + \eta \mathbf{w}_\tau(\mathbf{x}_i)\big) \big\|_2^2 .$$

---

[4]此速度不同于扩散时间 PF-ODE 的 $\mathbf{v}^*(\mathbf{x}, t)$；$t$ 或 s 描述加噪/去噪时间，τ 描述训练中模型分布的演化。

[5]此理想分布动力学不同于神经参数 ϕ 的普通梯度下降；后者受有限维生成器族约束，一般只能近似实现所需粒子移动。

[6]译注：能量耗散式以变分、积分分部及边界条件合法为前提；任意奇异分布、非光滑泛函或近似参数更新不自动满足该等式。

sg 表示停止梯度，把移动粒子作为固定目标。小参数更新 $\Delta\phi$ 下，

$$G_{\phi_\tau+\Delta\phi}(\mathbf{z}_i) \approx G_{\phi_\tau}(\mathbf{z}_i) + (\partial_\phi G_{\phi_\tau}(\mathbf{z}_i))\Delta\phi,$$

故参数更新近似求解

$$\min_{\Delta\phi} \frac{1}{N}\sum_{i=1}^{N} \|(\partial_\phi G_{\phi_\tau}(\mathbf{z}_i))\Delta\phi - \eta\mathbf{w}_\tau(\mathbf{x}_i)\|_2^2.$$

Wasserstein 梯度流指定理想粒子移动，神经训练则将其投影到改变有限维参数所能实现的移动集合。

正向 KL 训练：数据侧似然学习。 经典分布目标是数据侧（正向）KL：

$$D_{\mathrm{FKL}}(p_\phi, p_{\mathrm{data}}) := D_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi) = \int p_{\mathrm{data}}(\mathbf{x}) \log \frac{p_{\mathrm{data}}(\mathbf{x})}{p_\phi(\mathbf{x})} d\mathbf{x}.$$

数据分布固定，最小化它等价于最大似然（原式 1.1.2）：

$$\min_\phi D_{\mathrm{KL}}(p_{\mathrm{data}}\|p_\phi) \quad \Longleftrightarrow \quad \max_\phi \mathbb{E}_{\mathbf{x}\sim p_{\mathrm{data}}}[\log p_\phi(\mathbf{x})].$$

这是许多似然模型的分布视角。自回归模型与归一化流优化精确似然，似然 VAE 优化变分下界，EBM 通过正相和负相优化似然，扩散可经变分和去噪目标关联似然或得分匹配替代目标。

Wasserstein 视角下，正向 KL 第一变分为

$$\frac{\delta}{\delta p} D_{\mathrm{KL}}(p_{\mathrm{data}}\|p) = -\frac{p_{\mathrm{data}}}{p},$$

在 $p = p_{\phi_\tau}$ 处得到

$$\mathbf{w}_\tau^{\mathrm{FKL}}(\mathbf{x}) = \nabla_{\mathbf{x}} \left(\frac{p_{\mathrm{data}}(\mathbf{x})}{p_{\phi_\tau}(\mathbf{x})} \right).$$

它涉及隐式生成器通常难以估计的密度比。实践中，能得到似然、变分界或似然梯度适当近似时，正向 KL 或最大似然最直接。得分匹配则通过匹配得分学习分布，是另一条路线，并非直接实现正向 KL 的 Wasserstein 流。

正向 KL 的优势是倾向覆盖数据，且在似然或变分替代目标可用时具有坚实统计基础；局限是常需可解密度、变分界、得分匹配替代目标或昂贵负采样，因而不直接兼容任意隐式生成器。

逆向 KL 训练：模型侧得分失配动力学。 模型侧（逆向）KL 为

$$D_{\mathrm{RKL}}(p_\phi, p_{\mathrm{data}}) := D_{\mathrm{KL}}(p_\phi\|p_{\mathrm{data}}) = \int p_\phi(\mathbf{x}) \log \frac{p_\phi(\mathbf{x})}{p_{\mathrm{data}}(\mathbf{x})} d\mathbf{x}.$$

其一阶变分 $\delta D_{\mathrm{KL}}(p\|p_{\mathrm{data}})/\delta p = \log p - \log p_{\mathrm{data}} + 1$。在当前分布取值给出 Wasserstein 速度

$$\mathbf{w}_\tau^{\mathrm{RKL}}(\mathbf{x}) := \nabla_{\mathbf{x}} \log p_{\mathrm{data}}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\phi_\tau}(\mathbf{x}),$$

即“目标得分减去模型得分”的失配力。目标得分吸引粒子走向数据高密度区域，模型得分则把粒子从当前模型已经过度集中的区域推开。

扩散蒸馏与分布匹配（第 10.2 节）通常在噪声层级 s 应用此思想。令 p_s 为教师或加噪数据分布，$p_{\phi_\tau,s}$ 为当前生成样本加噪后的分布，目标

$$\mathbb{E}_s[w(s)D_{\mathrm{KL}}(p_{\phi_\tau,s}\|p_s)]$$

诱导得分失配速度

$$\mathbf{w}^{\mathrm{RKL}}_{\tau,s}(\mathbf{x}) := \nabla_{\mathbf{x}}\log p_s(\mathbf{x}) - \nabla_{\mathbf{x}}\log p_{\phi_\tau,s}(\mathbf{x}).$$

参数层面，对生成的含噪样本 $\widehat{\mathbf{x}}_s \sim p_{\phi_\tau,s}$，有如下形式梯度：

$$\nabla_\phi D_{\mathrm{KL}}(p_{\phi,s}\|p_s)\big|_{\phi=\phi_\tau} = \mathbb{E}_{\widehat{\mathbf{x}}_s\sim p_{\phi_\tau,s}}\left[\left(\nabla_{\mathbf{x}}\log p_{\phi_\tau,s}(\widehat{\mathbf{x}}_s) - \nabla_{\mathbf{x}}\log p_s(\widehat{\mathbf{x}}_s)\right)^\top \partial_\phi \widehat{\mathbf{x}}_s\right].$$

故得分差 $\nabla\log p_s(\widehat{\mathbf{x}}_s) - \nabla\log p_{\phi_\tau,s}(\widehat{\mathbf{x}}_s)$ 给出驱动参数梯度的分布下降方向。单粒子的实际移动仍通过共享参数化实现。DMD、VSD 等逆 KL 方法的基本机制正是：在生成样本上估计目标和模型得分，利用差更新生成器。

逆 KL 的优势是相关得分可估计后，自然兼容隐式生成器；其寻模态倾向可提高一至数步生成的视觉保真度。局限是可能丢失模态，强烈依赖得分估计质量，可能需要额外模型得分网络或强教师。同一吸引—排斥解释亦见于 drifting 式粒子更新（原引文键 weber2023the、deng2026generative）。按原引文键 lai2026unified 的术语，DMD/VSD/SiD 是得分失配动力学的参数化得分实例，而 drifting 方法是非参数核实例。[7]

结束语。 连续性方程是扩散动力学和分布层面训练的共同语言。扩散中它描述中间分布 p_t 如何沿预定加噪或概率流动力学变化；Wasserstein 梯度流中，它描述生成粒子移向数据时，模型分布如何在训练中演化。

这一观点将连续性方程的角色扩展到扩散之外：生成建模可以理解为设计分布动力学。不同方法选择不同差异、粒子速度与参数更新，把模型推向数据。由此，扩散、似然、分布匹配与得分失配方法可放在共享的分布层面分类中理解。

[7]译注：上述模态覆盖/寻模态是常用优化倾向描述，非所有参数族、目标权重和有限网络训练的必然结果；第一变分与路径梯度还需正密度、可积与可交换求导等条件。

附录 C　扩散模型的幕后：Itô 微积分与 Girsanov 定理

（基于得分的）扩散模型建立在 SDE 上：漂移推动状态，Brown 项使其抖动。Brown 路径处处不可微，普通链式法则不能直接套用。本章引入两种使数学表述精确的基本工具：

- **Itô 公式**是随机轨迹的正确链式法则，说明 $\mathbf{x}_t$ 遵循 SDE 时函数 $h(\mathbf{x}_t, t)$ 如何演化，可用于推导 Fokker–Planck 方程、矩动力学、Itô 乘积法则及得分训练恒等式。
- **Girsanov 定理**是路径概率的测度变换结果，量化保持噪声不变而改变漂移时似然如何变化，联系似然加权得分匹配、路径空间 KL，以及经变分界联系数据似然。

借助这些工具，可以清楚推导标准扩散模型的 Fokker–Planck 方程、逆时间 SDE、训练目标与似然关系，而不止依赖直觉。

学完本章后，你将能够：

- 理解普通微积分为何不足以处理 SDE，以及 Itô 公式如何给出正确随机链式法则；
- 看出 Itô 公式如何在 Fokker–Planck 与线性 SDE 等重要推导中起作用；
- 将 Girsanov 定理理解为比较漂移不同、扩散相同的随机路径概率的方法；
- 区分逐时分布匹配与完整随机路径匹配，理解似然加权得分匹配与路径 KL、数据似然的关系。

阅读路线。　本附录发展扩散模型幕后数学。Itô 微积分精确处理随机微分，Girsanov 定理解释改变漂移如何改变整条随机路径的概率；这些工具支撑了若干经常直接使用而不显式展示的标准推导。

C.1　Itô 公式：随机过程的链式法则

普通微积分不能直接用于 Wiener 过程，因为它在经典意义下不可微。Itô 微积分提供处理随机积分的规则。

C.1.1 动机：为何需要特殊链式法则？

对随时间光滑演化的确定性 $\mathbf{y}_t$（如 ODE），普通法则给出

$$\frac{dh}{dt} = \frac{\partial h}{\partial t} + (\nabla_{\mathbf{y}} h)\frac{d\mathbf{y}_t}{dt},$$

其中此行 $\nabla_{\mathbf{y}} h$ 表示 Jacobian，适用于确定性路径。于是问：

问题 C.1.1. *若 $\mathbf{x}_t$ 是随机过程，例如满足 $d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + g(t)d\mathbf{w}_t$，则 $h(\mathbf{x}_t, t)$ 满足什么 SDE？*

普通链式法则为何失效？ 天真套用会写成 $dh = \partial_t h\, dt + \nabla_{\mathbf{x}} h \cdot d\mathbf{x}_t$。但 Brown 增量尺度为 $O(\sqrt{dt})$，其二次变差在 Itô 记号中写为 $(dw_t)^2 = dt$，所以 dw_t 的二阶项不能像经典 $(dt)^2$ 那样忽略。

例：$h(x_t) = x_t^2$。 设标量 $dx_t = \sigma dw_t$，$x_0 = 0$，$\sigma > 0$ 为常数。经典法则若成立，就有 $dh = 2x_t\sigma dw_t$，并因

$$\mathbb{E}[dh] = 2\sigma\mathbb{E}[x_t dw_t] = 2\sigma\mathbb{E}[x_t]\underbrace{\mathbb{E}[dw_t]}_{=0} = 0$$

而使 $\mathbb{E}[h(x_t)]$ 不随时间变化。但 Brown 增量性质告诉我们 $\mathbb{E}[x_t^2] = \sigma^2 t$，它线性增长，说明普通法则漏掉了重要一项。[1]

C.1.2 由 Taylor 展开推导一维 Itô 公式

确定性链式法则的 Taylor 视角。 取标量 y_t 与标量函数 $h(y, t)$，形式上令 $dy_t = y_{t+dt} - y_t$，展开为

$$\begin{aligned} h(y_{t+dt}, t+dt) - h(y_t, t) &= \partial_t h\, dt + \partial_y h\, dy_t \\ &\quad + \frac{1}{2}\left[\partial_y^2 h (dy_t)^2 + 2\partial_t\partial_y h\, dt\, dy_t + \partial_t^2 h (dt)^2\right] + O(dt^3). \end{aligned}$$

$dt\, dy_t = (dy_t/dt)(dt)^2 = O(dt^2)$，其他二阶项也同阶，故忽略后

$$dh = \partial_t h\, dt + \partial_y h\, dy_t + O(dt^2).$$

随机 Taylor 展开。 现令 $dx_t = f(x_t, t)dt + g(t)dw_t$，求 $h(x_t, t)$ 的微分。随机 Taylor 展开（Kloeden et al., 1992）保留 dx_t 二阶项：

$$\begin{aligned} h(x_{t+dt}, t+dt) - h(x_t, t) &= \partial_t h\, dt + \partial_x h\, dx_t \\ &\quad + \frac{1}{2}\left[\partial_x^2 h (dx_t)^2 + 2\partial_t\partial_x h\, dt\, dx_t + \partial_t^2 h (dt)^2\right] + \cdots. \end{aligned}$$

Brown 尺度 $dw_t = O(\sqrt{dt})$ 给出 $dt\, dw_t = O((dt)^{3/2})$，故

$$dt\, dx_t = f(dt)^2 + g\, dt\, dw_t = O((dt)^{3/2}),$$

这些交叉项和更小项可忽略。[2]

[1] 译注：这里 dw_t 与过去独立的写法是增量启发记号；严格零均值使用适应、可积被积过程的 Itô 积分性质，而非把任意随机微分都当作独立变量相乘。

[2] 译注：此为源文启发式量级推导；Brown 增量的 $O(\sqrt{dt})$ 应按随机尺度理解，不是所有样本路径具有统一确定常数的逐点界。严格结果用二次变差及随机积分极限建立。

二阶项。 展开

$$\begin{aligned}(dx_t)^2 &= (f\,dt + g\,dw_t)^2 = f^2(dt)^2 + 2fg\,dt\,dw_t + g^2(dw_t)^2\\ &= g^2(t)dt,\end{aligned}$$

最后用 Itô 规则 $(dt)^2 = 0$、$dt\,dw_t = 0$、$(dw_t)^2 = dt$，末式按二次变差意义理解。于是

$$\begin{aligned}dh(x_t,t) &= \partial_t h\,dt + \partial_x h\,dx_t + \tfrac{1}{2}\partial_x^2 h\,g^2(t)dt\\ &= \left(\partial_t h + f\partial_x h + \tfrac{1}{2}g^2\partial_x^2 h\right)dt + g\partial_x h\,dw_t.\end{aligned}$$

这就是一维 Itô 公式。回到 $h(x_t) = x_t^2$ 的例子，正确结果为

$$d(x_t^2) = 2x_t dx_t + \sigma^2 dt = 2x_t\sigma dw_t + \sigma^2 dt,$$

补上了先前漏掉的项。

C.1.3 Itô 公式：SDE 的链式法则

上面的一维推导可类似推广到多维，这里省略详细证明，给出完整公式，再用它推导随机过程内积的乘积法则。

一维公式。 若 $dx_t = f(x_t,t)dt + g(t)dw_t$，对标量 $h:\mathbb{R}\times[0,T]\to\mathbb{R}$，

$$dh(x_t,t) = \left(\partial_t h + f\partial_x h + \tfrac{1}{2}g^2\partial_x^2 h\right)dt + g\partial_x h\,dw_t.$$

多维状态、标量输出。 若 $\mathbf{x}_t\in\mathbb{R}^D$ 满足 $d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t,t)dt + g(t)d\mathbf{w}_t$，$\mathbf{f}:\mathbb{R}^D\times[0,T]\to\mathbb{R}^D$，$g:[0,T]\to\mathbb{R}$，$\mathbf{w}_t$ 是 D 维标准 Brown 运动，则标量 $h:\mathbb{R}^D\times[0,T]\to\mathbb{R}$ 满足

$$dh(\mathbf{x}_t,t) = \left(\partial_t h + \nabla_{\mathbf{x}}h^\top\mathbf{f} + \frac{1}{2}g^2(t)\,\mathrm{Tr}(\nabla_{\mathbf{x}}^2 h)\right)dt + g(t)\nabla_{\mathbf{x}}h^\top d\mathbf{w}_t. \tag{C.1.1}$$

其中 $\nabla_{\mathbf{x}}h\in\mathbb{R}^D$ 为梯度，$\nabla_{\mathbf{x}}^2 h\in\mathbb{R}^{D\times D}$ 为 Hessian。[3]

例：Itô 乘积法则。 设 $\mathbf{x}_t,\mathbf{y}_t\in\mathbb{R}^D$，

$$\begin{aligned}d\mathbf{x}_t &= \mathbf{a}(\mathbf{x}_t,t)dt + b(t)d\mathbf{w}_t,\\ d\mathbf{y}_t &= \mathbf{c}(\mathbf{y}_t,t)dt + d(t)d\mathbf{w}_t,\end{aligned}$$

其中 $\mathbf{a},\mathbf{c}$ 为向量场，b,d 为标量函数，两过程由同一个 D 维 Brown 运动驱动。取 $z(t) = \mathbf{x}_t^\top\mathbf{y}_t$，对双线性函数 $h(\mathbf{x},\mathbf{y}) = \mathbf{x}^\top\mathbf{y}$ 应用多维公式，

$$\begin{aligned}d(\mathbf{x}^\top\mathbf{y}) &= (d\mathbf{x})^\top\mathbf{y} + \mathbf{x}^\top d\mathbf{y} + \mathrm{Tr}[d\mathbf{x}(d\mathbf{y})^\top],\\ d\mathbf{x}(d\mathbf{y})^\top &= b(t)d\mathbf{w}_t[d(t)d\mathbf{w}_t]^\top = b(t)d(t)dt\,\mathbf{I}_D.\end{aligned}$$

修正项迹为 $Db(t)d(t)dt$，因此

$$d(\mathbf{x}^\top\mathbf{y}) = (d\mathbf{x})^\top\mathbf{y} + \mathbf{x}^\top d\mathbf{y} + Db(t)d(t)dt. \tag{C.1.2}$$

[3]译注：标准公式要求 h 在时间一次、状态二次连续可微，过程与系数满足使积分有意义的条件；非光滑函数不能无条件照用。上一段 Jacobian 与此处列梯度的乘法方向须按输出维数区分。

C.1.4 应用：推导 Fokker–Planck 方程

用式 (C.1.1) 推导描述 SDE 密度演化的 PDE。

步骤 1：应用 Itô 公式。 取光滑检验函数 $\varphi:\mathbb{R}^D\times[0,T]\to\mathbb{R}$，有

$$d\varphi(\mathbf{x}_t,t)=\Big(\partial_t\varphi+\nabla\varphi^\top\mathbf{f}(\mathbf{x}_t,t)+\tfrac12 g^2(t)\,\mathrm{Tr}[\nabla^2\varphi]\Big)\,dt+g(t)\nabla\varphi^\top d\mathbf{w}_t.$$

步骤 2：取期望。 标准可积条件下 Itô 积分均值为零，故

$$\mathbb{E}[d\varphi]=\mathbb{E}\left[\Big(\partial_t\varphi+\nabla\varphi^\top\mathbf{f}+\tfrac12 g^2\,\mathrm{Tr}[\nabla^2\varphi]\Big)\,dt\right].$$

步骤 3：用密度表示。

$$\mathbb{E}[d\varphi]=\int\Big(\partial_t\varphi+\nabla\varphi^\top\mathbf{f}(\mathbf{x},t)+\tfrac12 g^2(t)\,\mathrm{Tr}[\nabla^2\varphi]\Big)\,p_t(\mathbf{x})d\mathbf{x}\,dt.$$

步骤 4：积分分部。 在无边界贡献或紧支撑检验函数等条件下，

$$\int\nabla\varphi^\top\mathbf{f}p_t\,d\mathbf{x}=-\int\varphi\nabla\cdot(\mathbf{f}p_t)d\mathbf{x},$$
$$\int\mathrm{Tr}[\nabla^2\varphi]p_t\,d\mathbf{x}=\int\varphi\Delta p_t\,d\mathbf{x}.$$

步骤 5：代入整理。 另有 $\mathbb{E}[\varphi(\mathbf{x}_t,t)]=\int\varphi(\mathbf{x},t)p_t(\mathbf{x})d\mathbf{x}$，故

$$\frac{d}{dt}\mathbb{E}[\varphi]=\int[(\partial_t\varphi)p_t+\varphi\partial_t p_t]d\mathbf{x},\qquad\mathbb{E}[d\varphi]=\left(\int[(\partial_t\varphi)p_t+\varphi\partial_t p_t]d\mathbf{x}\right)dt.$$

与步骤 3 比较，抵消 $\partial_t\varphi$ 项，再用步骤 4，得到

$$\int\varphi(\mathbf{x},t)\left[\partial_t p_t+\nabla\cdot(\mathbf{f}p_t)-\tfrac12 g^2(t)\Delta p_t\right]d\mathbf{x}=0.$$

任意光滑检验函数均成立，于是得到 Fokker–Planck 方程

$$\partial_t p_t(\mathbf{x})=-\nabla\cdot(\mathbf{f}(\mathbf{x},t)p_t(\mathbf{x}))+\tfrac12 g^2(t)\Delta p_t(\mathbf{x}).$$

C.1.5 应用：线性 SDE 的闭式解

与线性 ODE 类似，积分因子和 Itô 公式给出线性 SDE 解析解。考虑

$$d\mathbf{x}_t=f(t)\mathbf{x}_t dt+g(t)d\mathbf{w}_t,\tag{C.1.3}$$

其中 f,g 为确定性标量时间函数，$\mathbf{w}_t$ 为标准 Wiener 过程。此类正向 SDE 常见于第 4.1 节。

步骤 1：积分因子。 令 $\Psi(t):=\exp(-\int_0^t f(s)ds)$，定义 $\mathbf{y}_t:=\Psi(t)\mathbf{x}_t$。

步骤 2：Itô 公式。 对 $h(\mathbf{x},t)=\Psi(t)\mathbf{x}$ 应用乘积法则。Ψ 确定，无交叉变差项，

$$\begin{aligned}d\mathbf{y}_t&=\Psi'(t)\mathbf{x}_t dt+\Psi(t)d\mathbf{x}_t\\&=-f(t)\Psi(t)\mathbf{x}_t dt+\Psi(t)[f(t)\mathbf{x}_t dt+g(t)d\mathbf{w}_t]=\Psi(t)g(t)d\mathbf{w}_t.\end{aligned}$$

$\Psi(0)=1$，故 $\mathbf{y}_t=\mathbf{x}_0+\int_0^t\Psi(s)g(s)d\mathbf{w}_s$。

步骤 3：解出状态。

$$\mathbf{x}_t = e^{\int_0^t f(s)ds}\left[\mathbf{x}_0 + \int_0^t e^{-\int_0^s f(r)dr} g(s)d\mathbf{w}_s\right]. \tag{C.1.4}$$

这是向量值 SDE 的显式解。下面用两种方式计算 $p_t(\mathbf{x}_t \mid \mathbf{x}_0)$。

分析闭式解。 定义 $\phi(s) := e^{-\int_0^s f(u)du} g(s)$。它是确定性时间函数，$\int_0^t \phi(s)d\mathbf{w}_s$ 是零均值 Gaussian 向量；因此，给定初态的 $\mathbf{x}_t$ 是 Gaussian 变量的仿射变换，也为 Gaussian。[4]定义条件均值与协方差

$$\mathbf{m}(t) := \mathbb{E}[\mathbf{x}_t \mid \mathbf{x}_0], \qquad \mathbf{P}(t) := \mathbb{E}[(\mathbf{x}_t - \mathbf{m}(t))(\mathbf{x}_t - \mathbf{m}(t))^\top \mid \mathbf{x}_0].$$

积分均值为零，故

$$\mathbf{m}(t) = e^{\int_0^t f(s)ds}\mathbf{x}_0.$$

令 $\mathbf{z}_t := \int_0^t \phi(s)d\mathbf{w}_s$，$A(t) := e^{\int_0^t f(s)ds}$，则 $\mathbf{x}_t - \mathbf{m}(t) = A(t)\mathbf{z}_t$，且

$$\mathbf{P}(t) = e^{2\int_0^t f(s)ds}\mathbb{E}[\mathbf{z}_t\mathbf{z}_t^\top].$$

由 Itô 等距，[5]

$$\mathbb{E}[\mathbf{z}_t\mathbf{z}_t^\top] = \left(\int_0^t \phi^2(s)ds\right)\mathbf{I}_D,$$
$$\mathbf{P}(t) = e^{2\int_0^t f(s)ds}\left[\int_0^t \left(e^{-\int_0^s f(u)du} g(s)\right)^2 ds\right]\mathbf{I}_D.$$

这说明条件协方差各向同性。

推导原式 (4.4.3) 的均值和方差 ODE。 也可直接从 SDE 推出矩演化。取条件期望，

$$\frac{d\mathbf{m}(t)}{dt} = \mathbb{E}[f(t)\mathbf{x}_t \mid \mathbf{x}_0] = f(t)\mathbf{m}(t).$$

令中心过程 $\widetilde{\mathbf{x}}_t := \mathbf{x}_t - \mathbf{m}(t)$，则

$$d(\widetilde{\mathbf{x}}_t\widetilde{\mathbf{x}}_t^\top) = d\widetilde{\mathbf{x}}_t\,\widetilde{\mathbf{x}}_t^\top + \widetilde{\mathbf{x}}_t\,d\widetilde{\mathbf{x}}_t^\top + d\widetilde{\mathbf{x}}_t\,d\widetilde{\mathbf{x}}_t^\top,$$
$$d\widetilde{\mathbf{x}}_t = f(t)\widetilde{\mathbf{x}}_t dt + g(t)d\mathbf{w}_t.$$

代入并取期望：

$$\frac{d\mathbf{P}(t)}{dt} = \mathbb{E}[f(t)\widetilde{\mathbf{x}}_t\widetilde{\mathbf{x}}_t^\top + \widetilde{\mathbf{x}}_t\widetilde{\mathbf{x}}_t^\top f(t) + g^2(t)\mathbf{I}_D] = 2f(t)\mathbf{P}(t) + g^2(t)\mathbf{I}_D,$$

即恢复原式 (4.4.3)。

---

[4]译注：源文此处称 ϕ 为 “矩阵值”，但在本小节标量 f, g 的设定下，ϕ 是标量，或等价为 $\phi\mathbf{I}_D$；后面的 $\phi^2\mathbf{I}_D$ 与各向同性协方差依赖这一设定，不能直接用于一般矩阵噪声。

[5]Itô 等距联系随机积分与普通积分的期望，此处略去需完整随机微积分的证明。对适当平方可积适应过程 $\psi : [0,T] \to \mathbb{R}^{D\times D}$，$\mathbb{E}[\|\int_0^T \psi(t)d\mathbf{w}_t\|_2^2] = \mathbb{E}[\int_0^T \|\psi(t)\|_F^2 dt]$，其中 $\|\psi\|_F^2 = \sum_{i,j=1}^D |\psi_{ij}|^2$。对向量 $\psi(t) \in \mathbb{R}^D$，积分 $\int \psi^\top d\mathbf{w}$ 为标量，等距为 $\mathbb{E}[(\int_0^T \psi(t)^\top d\mathbf{w}_t)^2] = \mathbb{E}[\int_0^T \|\psi(t)\|_2^2 dt]$。

C.2 测度的变量变换：扩散模型中的 Girsanov 定理

扩散模型用 SDE 将简单噪声变为丰富数据分布，背后有一个深刻思想：只修改确定性部分（漂移）、保留底层随机性，就能重新赋予随机路径权重。Girsanov 定理正用于此。

核心思想。 设观测到一条从 0 到 T 的连续路径 $\mathbf{x}_{0:T} := \{\mathbf{x}_t : t \in [0,T]\}$。问题是：

问题 C.2.1. *对同一条观测路径，假设它由一种 SDE 生成，与假设由另一种 SDE 生成时，其似然如何比较？*

比较两种假想生成模型，它们初始分布、扩散系数相同，确定性推动——漂移——不同。可将路径想成画在纸上的曲折线：一种假设用漂移 $\mathbf{f}$ 分配路径概率，另一种以相同扩散、不同漂移 $\widetilde{\mathbf{f}}$ 分配概率。定理比较对应路径测度，量化漂移改变如何改变相同轨迹的相对权重。[6]

设定。 令 $\mathbb{P}_{\mathbf{f}}, \mathbb{P}_{\widetilde{\mathbf{f}}}$ 为以下两 SDE 诱导的路径测度：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + g(t)d\mathbf{w}_t,$$
$$d\mathbf{x}_t = \widetilde{\mathbf{f}}(\mathbf{x}_t, t)dt + g(t)d\mathbf{w}_t.$$

假定初始分布相同，为简单起见，相关区间 $g(t) > 0$，并满足 Girsanov 所需标准可积条件。以 $\mathbb{P}_{\widetilde{\mathbf{f}}}$ 为参考测度，$\mathbf{w}_t$ 为该测度下的 Brown 运动。定义 $\boldsymbol{\delta}_t := \mathbf{f}(\mathbf{x}_t, t) - \widetilde{\mathbf{f}}(\mathbf{x}_t, t)$。

Girsanov 似然比。 定理给出

$$\frac{d\mathbb{P}_{\mathbf{f}}}{d\mathbb{P}_{\widetilde{\mathbf{f}}}}(\mathbf{x}_{0:T}) = \exp\left(\int_0^T \boldsymbol{\delta}_t^\top g(t)^{-1} d\mathbf{w}_t - \frac{1}{2}\int_0^T \|g(t)^{-1}\boldsymbol{\delta}_t\|_2^2 dt\right).$$

指数中第一项是 Itô 积分，第二项是普通时间积分（源文称 Riemann 积分；一般按相应可积意义理解）。它使我们能比较随机动力学，并联系路径空间差异与似然训练目标。[7]

最好把 Girsanov 理解为测度的变量变换公式。经典微积分用 Jacobian 行列式在坐标系之间变换积分；Girsanov 在扩散不变、漂移改变时，以 Radon–Nikodym 导数为对应因子，在随机过程之间变换概率或期望。

C.2.1 Girsanov 定理：连接似然训练与得分匹配

理解不同漂移假设下同一路径的似然关系后，再看它对扩散模型的含义。正向 SDE

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + g(t)d\mathbf{w}_t$$

诱导完整轨迹的联合路径分布 $\mathbb{P}$。以可学习得分 $\mathbf{s}_\phi$ 参数化的逆时间 SDE 为

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g^2(t)\mathbf{s}_\phi(\mathbf{x}_t, t)]dt + g(t)d\bar{\mathbf{w}}_t,$$

它定义另一条路径分布 $\mathbb{P}_\phi$；此行沿扩散时间递减积分。

[6]译注：连续路径空间中一条精确路径通常概率为零；这里“路径似然比”严格指路径测度间 Radon–Nikodym 密度，而非两条非零单点概率相除。

[7]译注：标准条件须保证指数局部鞅是均值 1 的真鞅，例如适当 Novikov 型条件；仅形式写出指数并不自动给出有效概率测度。此式 Brown 运动属于参考测度，不能换测度后仍不加说明地沿用。

扩散模型中的两种一致性。

- **边缘分布匹配：**每个固定 t 的分布 $p_t(\mathbf{x}_t)$ 相同，逐时“快照”一致。
- **联合路径分布匹配：**整条轨迹的概率律相同，更强地匹配不同时刻的耦合、转移律与时间依赖。

完整路径匹配自动推出边缘匹配，因为边缘是路径在某一时刻的投影；反之通常不成立。SDE 与关联 PF-ODE 便是重要例子：密度路径相同，样本轨迹和路径律通常不同。

Girsanov 联系得分误差与路径律失配。 精确逆时间 SDE 满足更强概念。在标准正则条件下，从精确终端边缘 p_T 初始化，并使用真实得分 $\nabla_{\mathbf{x}} \log p_t$，所得过程是正向扩散的时间反转，再现完整反向路径律。

令 $\mathbb{P}^{\text{rev}}$ 为精确逆路径律，$\mathbb{P}_\phi$ 为以学习得分替代真得分、从 p_{prior} 初始化的逆路径律。将路径 KL 分解为初始分布失配与条件路径律失配，把两过程改写到同一递增逆时间时钟后对后者应用 Girsanov，再用原扩散时间 t 标记，得

$$D_{\text{KL}}(\mathbb{P}^{\text{rev}} \| \mathbb{P}_\phi) = D_{\text{KL}}(p_T \| p_{\text{prior}}) + \frac{1}{2} \int_0^T g^2(t) \mathbb{E}_{\mathbf{x}_t \sim p_t} \left[\| \mathbf{s}_\phi(\mathbf{x}_t, t) - \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) \|_2^2 \right] dt. \tag{C.2.1}$$

第一项衡量真实终端分布与生成初始化先验的失配，$p_T = p_{\text{prior}}$ 时消失；第二项衡量学习与精确逆漂移的累积失配。

因此，以特定似然权重 $g^2(t)$ 做得分匹配，具有直接路径空间解释：忽略固定终端分布项后，最小化加权得分误差就是最小化精确与学习逆路径律的 KL。用去噪得分匹配替代边缘得分匹配时，对应目标只差不依赖参数的常数。一般改变时间权重后，不再对应同一个路径 KL。[8]

与数据似然的联系。 取路径端点是可测投影，KL 在边缘化下不增加，因而

$$D_{\text{KL}}(p_{\text{data}} \| p_\phi) \le D_{\text{KL}}(\mathbb{P}^{\text{rev}} \| \mathbb{P}_\phi), \tag{C.2.2}$$

其中 p_ϕ 为数据时刻的生成边缘。结合式 (C.2.1)，似然加权得分匹配加终端失配给出数据侧 KL 上界，从而在加上不依赖 ϕ 的常数后，给出期望负对数似然的上界（Song et al., 2021）。

[8]译注：等式还使用初始绝对连续性、相同非退化扩散、适当可积性及合法测度变换；若终端 KL 或积分发散，不能按有限训练损失无条件解释。不能把正向递增时钟与逆向递减时钟中的漂移差直接混算。

附录 D　补充材料与证明

D.1　变分视角

D.1.1　定理 2.2.1：边缘与条件 KL 最小化的等价性

原式 (2.2.3) 的推导. 从右侧期望展开：

$$\begin{aligned}&\mathbb{E}_{p(\mathbf{x}_0,\mathbf{x}_i)}[D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i))]\\&=\iint p(\mathbf{x}_0,\mathbf{x}_i)D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i))d\mathbf{x}_0d\mathbf{x}_i.\end{aligned}$$

按 KL 定义，内项为

$$\int p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}d\mathbf{x}_{i-1}.$$

代入即三重积分。再用概率链式法则 $p(\mathbf{x}_0,\mathbf{x}_i)=p(\mathbf{x}_i)p(\mathbf{x}_0\mid\mathbf{x}_i)$，将其写为

$$\iiint p(\mathbf{x}_i)p(\mathbf{x}_0\mid\mathbf{x}_i)p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}d\mathbf{x}_{i-1}d\mathbf{x}_0d\mathbf{x}_i,$$

即嵌套期望

$$\mathbb{E}_{p(\mathbf{x}_i)}\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)}\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}\left[\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}\right].$$

将对数分解为

$$\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}=\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)}{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}+\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}.$$

代回得到两项嵌套期望。第二个对数不含 $\mathbf{x}_0$，全概率公式给出

$$\begin{aligned}&\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)}\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i,\mathbf{x}_0)}\left[\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}\right]\\&=\mathbb{E}_{p(\mathbf{x}_{i-1}|\mathbf{x}_i)}\left[\log\frac{p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}{p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)}\right].\end{aligned}$$

第一项则是 $\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)}D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p(\mathbf{x}_{i-1}\mid\mathbf{x}_i))$。合并得

$$\begin{aligned}&\mathbb{E}_{p(\mathbf{x}_0,\mathbf{x}_i)}D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i))\\&=\mathbb{E}_{p(\mathbf{x}_i)}\mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)}D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i,\mathbf{x}_0)\|p(\mathbf{x}_{i-1}\mid\mathbf{x}_i))\\&\quad+\mathbb{E}_{p(\mathbf{x}_i)}D_{\mathrm{KL}}(p(\mathbf{x}_{i-1}\mid\mathbf{x}_i)\|p_\phi(\mathbf{x}_{i-1}\mid\mathbf{x}_i)).\end{aligned}$$

最优性。因此，在参数化足够丰富时，最优核为

$$p^*(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = \mathbb{E}_{p(\mathbf{x}_0|\mathbf{x}_i)}[p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)], \quad \mathbf{x}_i \sim p_i.$$

第一式因为 KL 在模型等于目标时最小，第二式直接来自全概率公式。[1] □

D.1.2 定理 2.2.3：扩散模型的 ELBO

证明. 简记 $\mathbf{x}_{1:L} = (\mathbf{x}_1, \ldots, \mathbf{x}_L)$。

步骤 1：Jensen 不等式。生成联合分布与边缘为

$$p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) = p_{\text{prior}}(\mathbf{x}_L) \prod_{i=1}^{L} p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i),$$
$$\log p_\phi(\mathbf{x}_0) = \log \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) d\mathbf{x}_{1:L}.$$

引入正向分布 $p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = \prod_{i=1}^{L} p(\mathbf{x}_i \mid \mathbf{x}_{i-1})$，重写为

$$\begin{aligned}\log p_\phi(\mathbf{x}_0) &= \log \int p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) \frac{p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})}{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} d\mathbf{x}_{1:L} \\ &\geq \mathbb{E}_{p(\mathbf{x}_{1:L}|\mathbf{x}_0)} \left[\log \frac{p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L})}{p(\mathbf{x}_{1:L} \mid \mathbf{x}_0)} \right] =: \mathcal{L}_{\text{ELBO}}(\mathbf{x}_0; \phi).\end{aligned}$$

故 $-\log p_\phi(\mathbf{x}_0) \leq -\mathcal{L}_{\text{ELBO}}(\mathbf{x}_0; \phi)$。

步骤 2：展开。代入因子分解，

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}\left[\log p_{\text{prior}}(\mathbf{x}_L) + \sum_{i=1}^{L} \log p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) - \sum_{i=1}^{L} \log p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \right].$$

Markov 结构还给出 $p(\mathbf{x}_{1:L} \mid \mathbf{x}_0) = p(\mathbf{x}_L \mid \mathbf{x}_0) \prod_{i=2}^{L} p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)$，于是

$$-\mathcal{L}_{\text{ELBO}} = \mathbb{E}\left[\log \frac{p(\mathbf{x}_L \mid \mathbf{x}_0)}{p_{\text{prior}}(\mathbf{x}_L)} + \sum_{i=2}^{L} \log \frac{p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0)}{p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)} - \log p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1) \right].$$

按依赖关系分组，

$$\begin{aligned}-\mathcal{L}_{\text{ELBO}} = &\underbrace{\mathbb{E}_{p(\mathbf{x}_L|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_L \mid \mathbf{x}_0)}{p_{\text{prior}}(\mathbf{x}_L)} \right]}_{\mathcal{L}_{\text{prior}}(\mathbf{x}_0)} + \underbrace{\mathbb{E}_{p(\mathbf{x}_1|\mathbf{x}_0)}[-\log p_\phi(\mathbf{x}_0 \mid \mathbf{x}_1)]}_{\mathcal{L}_{\text{recon.}}(\mathbf{x}_0;\phi)} \\ &+ \underbrace{\sum_{i=2}^{L} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} D_{\text{KL}}(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i))}_{\mathcal{L}_{\text{diffusion}}(\mathbf{x}_0;\phi)}.\end{aligned}$$

即得所述分解。 □

[1] 译注：分解以相关 KL 和积分有意义为前提，不进行 $\infty - \infty$ 相减；最优核等式按边缘几乎处处理解，有限网络未必能实现无约束最优。

D.2 得分视角

D.2.1 命题 3.2.1：通过积分分部得到可解得分匹配

证明. 展开平方，$\mathbf{s} = \nabla \log p_{\text{data}}$，则

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi) &= \frac{1}{2}\mathbb{E}_{\mathbf{x}\sim p_{\text{data}}}[\|\mathbf{s}_\phi\|_2^2 - 2\langle \mathbf{s}_\phi, \mathbf{s}\rangle + \|\mathbf{s}\|_2^2] \\ &= \tfrac{1}{2}\mathbb{E}\|\mathbf{s}_\phi\|_2^2 - \mathbb{E}\langle \mathbf{s}_\phi, \mathbf{s}\rangle + \tfrac{1}{2}\mathbb{E}\|\mathbf{s}\|_2^2.\end{aligned}$$

在密度非零处，$\nabla \log p_{\text{data}} = \nabla p_{\text{data}}/p_{\text{data}}$，交叉项化为

$$\begin{aligned}\mathbb{E}\langle \mathbf{s}_\phi, \mathbf{s}\rangle &= \int \mathbf{s}_\phi(\mathbf{x})^\top \nabla \log p_{\text{data}}(\mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x} \\ &= \int \mathbf{s}_\phi^\top \nabla p_{\text{data}} d\mathbf{x} = \sum_{i=1}^{D} \int s_\phi^{(i)}(\mathbf{x}) \partial_{x_i} p_{\text{data}}(\mathbf{x}) d\mathbf{x}.\end{aligned}$$

其中 $s_\phi^{(i)}$ 是得分向量第 i 项。

积分分部引理。对球 $B(0,R) \subset \mathbb{R}^D$ 上可微实函数 u, v，$i = 1, \ldots, D$，有（Evans, 2010）

$$\int_{B(0,R)} u \partial_{x_i} v \, d\mathbf{x} = -\int_{B(0,R)} v \partial_{x_i} u \, d\mathbf{x} + \int_{\partial B(0,R)} uv \nu_i \, dS,$$

其中 $\boldsymbol{\nu}$ 是球面外单位法向。取 $u = s_\phi^{(i)}$、$v = p_{\text{data}}$，并假设无穷远边界项消失，源文以 $|uv| \to 0$（$R \to \infty$）表达衰减，求和得

$$\mathbb{E}\langle \mathbf{s}_\phi, \mathbf{s}\rangle = -\sum_{i=1}^{D} \int \partial_{x_i} s_\phi^{(i)} p_{\text{data}} d\mathbf{x} = -\mathbb{E}[\text{Tr}(\nabla \mathbf{s}_\phi)].$$

故

$$\mathcal{L}_{\text{SM}}(\phi) = \underbrace{\mathbb{E}[\text{Tr}(\nabla \mathbf{s}_\phi) + \tfrac{1}{2}\|\mathbf{s}_\phi\|_2^2]}_{\widetilde{\mathcal{L}}_{\text{SM}}(\phi)} + \underbrace{\tfrac{1}{2}\mathbb{E}\|\mathbf{s}\|_2^2}_{C},$$

C 只依赖数据分布，证毕。[2] □

D.2.2 定理 3.3.1：SM 与 DSM 最小化等价

证明. 展开两目标：

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi;\sigma) &= \tfrac{1}{2}\mathbb{E}_{\widetilde{\mathbf{x}}\sim p_\sigma}\big[\|\mathbf{s}_\phi\|_2^2 - 2\mathbf{s}_\phi^\top \nabla \log p_\sigma(\widetilde{\mathbf{x}}) + \|\nabla \log p_\sigma(\widetilde{\mathbf{x}})\|_2^2\big], \\ \mathcal{L}_{\text{DSM}}(\phi;\sigma) &= \tfrac{1}{2}\mathbb{E}_{p_{\text{data}}(\mathbf{x})p_\sigma(\widetilde{\mathbf{x}}|\mathbf{x})}\big[\|\mathbf{s}_\phi\|_2^2 - 2\mathbf{s}_\phi^\top \nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) + \|\nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x})\|_2^2\big],\end{aligned}$$

其中 $\mathbf{s}_\phi = \mathbf{s}_\phi(\widetilde{\mathbf{x}};\sigma)$，梯度均对 $\widetilde{\mathbf{x}}$。相减分三组：

$$\begin{aligned}\mathcal{L}_{\text{SM}} - \mathcal{L}_{\text{DSM}} = &\tfrac{1}{2}\left(\mathbb{E}_{p_\sigma}\|\mathbf{s}_\phi\|_2^2 - \mathbb{E}_{p_{\text{data}}p_\sigma(\cdot|\mathbf{x})}\|\mathbf{s}_\phi\|_2^2\right) \\ &- \Big(\mathbb{E}_{p_\sigma}[\mathbf{s}_\phi^\top \nabla \log p_\sigma] - \mathbb{E}_{p_{\text{data}}p_\sigma(\cdot|\mathbf{x})}[\mathbf{s}_\phi^\top \nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x})]\Big) \\ &+ \tfrac{1}{2}\left(\mathbb{E}_{p_\sigma}\|\nabla \log p_\sigma\|_2^2 - \mathbb{E}_{p_{\text{data}}p_\sigma(\cdot|\mathbf{x})}\|\nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x})\|_2^2\right).\end{aligned}$$

[2] 译注：多维中 uv 逐点趋零不自动使面积随 R 增长的球面积分趋零；严格要求边界通量消失并有足够可积/交换极限条件，原文简写不能当作完整充分条件。

三组依次是网络平方范数期望之差、负交叉项期望之差，以及真实得分平方范数期望之差的一半。

第一组由 $p_\sigma(\widetilde{\mathbf{x}}) = \int p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}$ 得

$$\begin{aligned}\mathbb{E}_{p_\sigma} \|\mathbf{s}_\phi\|_2^2 &= \int \left(\int p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x} \right) \|\mathbf{s}_\phi(\widetilde{\mathbf{x}}; \sigma)\|_2^2 d\widetilde{\mathbf{x}} \\ &= \int p_{\text{data}}(\mathbf{x}) \int p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) \|\mathbf{s}_\phi(\widetilde{\mathbf{x}}; \sigma)\|_2^2 d\widetilde{\mathbf{x}} d\mathbf{x},\end{aligned}$$

等于联合期望，故差为零。第二组中，

$$\begin{aligned}\mathbb{E}_{p_\sigma}[\mathbf{s}_\phi^\top \nabla \log p_\sigma] &= \int p_\sigma(\widetilde{\mathbf{x}}) \mathbf{s}_\phi^\top \frac{\nabla p_\sigma(\widetilde{\mathbf{x}})}{p_\sigma(\widetilde{\mathbf{x}})} d\widetilde{\mathbf{x}} \\ &= \int \mathbf{s}_\phi^\top \nabla \int p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x}) d\mathbf{x}\, d\widetilde{\mathbf{x}} \\ &= \iint \mathbf{s}_\phi^\top \nabla p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x}) p_{\text{data}}(\mathbf{x}) d\widetilde{\mathbf{x}} d\mathbf{x} \\ &= \mathbb{E}_{p_{\text{data}} p_\sigma(\cdot \mid \mathbf{x})}[\mathbf{s}_\phi^\top \nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x})]. \end{aligned} \tag{D.2.1}$$

故第二组也为零。第三组

$$C := \tfrac{1}{2} \left(\mathbb{E}_{p_\sigma} \|\nabla \log p_\sigma(\widetilde{\mathbf{x}})\|_2^2 - \mathbb{E}_{p_{\text{data}} p_\sigma(\cdot \mid \mathbf{x})} \|\nabla \log p_\sigma(\widetilde{\mathbf{x}} \mid \mathbf{x})\|_2^2 \right)$$

只依赖数据与破坏核，与 ϕ 无关。因此两目标相差常数；各积分、求导交换使用相应正则条件。 □

D.2.3 引理 3.3.2：Tweedie 公式

先给出含时变 Gaussian 扰动的更一般形式。若 $\mathbf{x}_t \mid \mathbf{x}_0 \sim \mathcal{N}(\alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$，则

$$\alpha_t \mathbb{E}_{p(\mathbf{x}_0 \mid \mathbf{x}_t)}[\mathbf{x}_0 \mid \mathbf{x}_t] = \mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

期望针对给定观测的干净状态后验，p_t 是含噪状态边缘。

证明. 边缘与得分为

$$\begin{aligned} p_t(\mathbf{x}_t) &= \int p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0, \\ \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) &= \frac{1}{p_t(\mathbf{x}_t)} \int \nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0. \end{aligned}$$

Gaussian 条件密度的梯度为 $\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t \mid \mathbf{x}_0) = -p_t(\mathbf{x}_t \mid \mathbf{x}_0) \sigma_t^{-2} (\mathbf{x}_t - \alpha_t \mathbf{x}_0)$，代入：

$$\begin{aligned}\nabla_{\mathbf{x}_t} p_t(\mathbf{x}_t) &= -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p_t(\mathbf{x}_t \mid \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0 \\ &= -\sigma_t^{-2} \int (\mathbf{x}_t - \alpha_t \mathbf{x}_0) p(\mathbf{x}_0 \mid \mathbf{x}_t) p_t(\mathbf{x}_t) d\mathbf{x}_0 \\ &= -p_t(\mathbf{x}_t) \sigma_t^{-2} \left(\mathbf{x}_t - \alpha_t \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t] \right).\end{aligned}$$

两侧除以边缘密度并整理即得。此推导要求 $\sigma_t > 0$、相关后验矩存在，且在正边缘密度处使用。 □

D.2.4 Stein 恒等式与 SURE 替代目标

Stein 恒等式借助积分分部，将未知密度下的期望变成可观测函数及其导数的期望，消去配分函数，从而构造不求值未知密度或配分函数的无偏、可解目标与检验。

一维标准正态。若 $z \sim \mathcal{N}(0,1)$，f 具有合适衰减，则 $\mathbb{E}[f'(z)] = \mathbb{E}[zf(z)]$。令 $\varphi(z) = (2\pi)^{-1/2} e^{-z^2/2}$，有 $\varphi' = -z\varphi$。于是

$$\begin{aligned}\mathbb{E}[f'(z)] &= \int_{-\infty}^{\infty} f'(z)\varphi(z)dz \\ &= [f(z)\varphi(z)]_{-\infty}^{\infty} - \int f(z)\varphi'(z)dz = \int f(z)z\varphi(z)dz = \mathbb{E}[zf(z)],\end{aligned}$$

其中边界项由 $f\varphi \to 0$ 消失。

多维标准正态。若 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_D)$，$g : \mathbb{R}^D \to \mathbb{R}$，则 $\mathbb{E}[\nabla g(\mathbf{z})] = \mathbb{E}[\mathbf{z}g(\mathbf{z})]$。等价地，向量函数 $\mathbf{u} : \mathbb{R}^D \to \mathbb{R}^D$ 满足

$$\mathbb{E}[\nabla_{\mathbf{z}} \cdot \mathbf{u}(\mathbf{z})] = \mathbb{E}[\mathbf{z}^\top \mathbf{u}(\mathbf{z})]. \tag{D.2.2}$$

SURE 所需恒等式。对 $\widetilde{\mathbf{x}} = \mathbf{x} + \sigma\mathbf{z}$ 和适当正则向量函数 $\mathbf{a}$，链式法则及式 (D.2.2) 给出

$$\mathbb{E}[(\widetilde{\mathbf{x}} - \mathbf{x})^\top \mathbf{a}(\widetilde{\mathbf{x}}) \mid \mathbf{x}] = \sigma^2 \mathbb{E}[\nabla_{\widetilde{\mathbf{x}}} \cdot \mathbf{a}(\widetilde{\mathbf{x}}) \mid \mathbf{x}]. \tag{D.2.3}$$

从条件 MSE 推导 SURE。设去噪器 $\mathsf{D} : \mathbb{R}^D \to \mathbb{R}^D$，为避免与维数 D 混淆，译稿用不同字体区分。定义

$$R(\mathsf{D}; \mathbf{x}) := \mathbb{E}[\|\mathsf{D}(\widetilde{\mathbf{x}}) - \mathbf{x}\|_2^2 \mid \mathbf{x}].$$

在 $\widetilde{\mathbf{x}}$ 周围展开，

$$\begin{aligned}R &= \mathbb{E}[\|\mathsf{D}(\widetilde{\mathbf{x}}) - \widetilde{\mathbf{x}}\|_2^2 \mid \mathbf{x}] + 2\mathbb{E}[(\mathsf{D}(\widetilde{\mathbf{x}}) - \widetilde{\mathbf{x}})^\top (\widetilde{\mathbf{x}} - \mathbf{x}) \mid \mathbf{x}] \\ &\quad + \mathbb{E}[\|\widetilde{\mathbf{x}} - \mathbf{x}\|_2^2 \mid \mathbf{x}] \\ &= \mathbb{E}[\|\mathsf{D}(\widetilde{\mathbf{x}}) - \widetilde{\mathbf{x}}\|_2^2 \mid \mathbf{x}] + 2\left(\underbrace{\mathbb{E}[(\widetilde{\mathbf{x}} - \mathbf{x})^\top \mathsf{D}(\widetilde{\mathbf{x}}) \mid \mathbf{x}]}_{\sigma^2 \mathbb{E}[\nabla \cdot \mathsf{D} \mid \mathbf{x}]} - \underbrace{\mathbb{E}[(\widetilde{\mathbf{x}} - \mathbf{x})^\top \widetilde{\mathbf{x}} \mid \mathbf{x}]}_{\sigma^2 D} \right) + \sigma^2 D \\ &= \mathbb{E}[\|\mathsf{D}(\widetilde{\mathbf{x}}) - \widetilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla \cdot \mathsf{D}(\widetilde{\mathbf{x}}) - D\sigma^2 \mid \mathbf{x}].\end{aligned}$$

故可观测替代目标

$$\mathrm{SURE}(\mathsf{D}; \widetilde{\mathbf{x}}) := \|\mathsf{D}(\widetilde{\mathbf{x}}) - \widetilde{\mathbf{x}}\|_2^2 + 2\sigma^2 \nabla \cdot \mathsf{D}(\widetilde{\mathbf{x}}) - D\sigma^2$$

满足 $\mathbb{E}[\mathrm{SURE}(\mathsf{D}; \widetilde{\mathbf{x}}) \mid \mathbf{x}] = R(\mathsf{D}; \mathbf{x})$。源文据此称可仅凭含噪观测，在期望或经验上最小化 SURE 来最小化真实条件 MSE。[3]

[3]译注：严格等价是期望风险层面；有限样本的经验 SURE 具有估计波动，不能保证其经验最优点等于未知干净 MSE 的经验最优点，还须考虑同数据选模型导致的选择效应。

D.2.5 定理 4.2.1：通过 Fokker–Planck 对齐边缘

证明. **第一部分：正向 SDE 的 Fokker–Planck 方程**。对 $d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + g(t)d\mathbf{w}$，扩散矩阵 $\boldsymbol{\sigma}(t) = g(t)\mathbf{I}_D$，故 $\boldsymbol{\sigma}\boldsymbol{\sigma}^\top = g^2\mathbf{I}_D$，

$$\partial_t p_t = -\nabla \cdot (\mathbf{f} p_t) + \frac{1}{2}\sum_{i,j=1}^{D} \partial_{x_i}\partial_{x_j}[g^2(t)\delta_{ij}p_t],$$

$$\sum_{i,j} \partial_{x_i}\partial_{x_j}[g^2\delta_{ij}p_t] = \sum_i \partial^2_{x_i}[g^2 p_t] = g^2\Delta p_t.$$

定义 $\mathbf{v} = \mathbf{f} - \frac{1}{2}g^2\nabla \log p_t$。由 $\nabla \log p_t = \nabla p_t / p_t$，

$$\nabla \cdot (\mathbf{v}p_t) = \nabla \cdot \left[\mathbf{f}p_t - \tfrac{1}{2}g^2(\nabla p_t/p_t)p_t\right] = \nabla \cdot (\mathbf{f}p_t) - \tfrac{1}{2}g^2\Delta p_t,$$

所以 $\partial_t p_t = -\nabla \cdot (\mathbf{v}p_t)$，验证两种形式。

第二部分：PF-ODE 的边缘。考虑 $d\widetilde{\mathbf{x}}/dt = \mathbf{v}(\widetilde{\mathbf{x}}, t)$。正向从 $\widetilde{\mathbf{x}}(0) \sim p_0$ 出发，定义流

$$\frac{d}{dt}\Psi_t(\mathbf{x}_0) = \mathbf{v}(\Psi_t(\mathbf{x}_0), t), \qquad \Psi_0(\mathbf{x}_0) = \mathbf{x}_0.$$

$\widetilde{\mathbf{x}}(t) = \Psi_t(\widetilde{\mathbf{x}}(0))$ 的密度 $\widetilde{p}_t$ 满足 $\partial_t \widetilde{p}_t = -\nabla \cdot (\mathbf{v}\widetilde{p}_t)$，初态为 p_0。第一部分说明 p_t 也满足同一 PDE 及初态。在足够光滑并保证适当函数空间唯一性等条件下，两解相同，故 $\widetilde{\mathbf{x}}(t) \sim p_t$。

反向从 $\widetilde{\mathbf{x}}(T) \sim p_T$ 出发仍用同一 ODE。令 $s = T - t$，则

$$\frac{d}{ds}\widetilde{\mathbf{x}}(T-s) = -\mathbf{v}(\widetilde{\mathbf{x}}(T-s), T-s).$$

密度满足 $\partial_s \widetilde{p}_{T-s} = \nabla \cdot (\mathbf{v}(\mathbf{x}, T-s)\widetilde{p}_{T-s})$，$s = 0$ 初态为 p_T。原 p_t 由 $\partial_t = -\partial_s$ 也满足此式与初态。唯一性推出 $\widetilde{p}_{T-s} = p_{T-s}$，即所有 t 都有 $\widetilde{\mathbf{x}}(t) \sim p_t$。

第三部分：逆时间 SDE 的边缘。用递增逆时钟 $s = T - t$，定义 $\mathbf{y}(s) := \bar{\mathbf{x}}(T-s)$。原逆过程从 $\bar{\mathbf{x}}(T) \sim p_T$ 开始，故 $\mathbf{y}(0) \sim p_T$，且

$$d\mathbf{y}(s) = [-\mathbf{f}(\mathbf{y}(s), T-s) + g^2(T-s)\nabla \log p_{T-s}(\mathbf{y}(s))]ds + g(T-s)d\mathbf{w}_{\mathrm{rev}}(s),$$

其中 $\mathbf{w}_{\mathrm{rev}}$ 是递增时钟下标准 Wiener 过程。设密度为 q_s，其 FP 方程为

$$\partial_s q_s = -\nabla \cdot \left[(-\mathbf{f}(\mathbf{x}, T-s) + g^2(T-s)\nabla \log p_{T-s}(\mathbf{x}))q_s\right] + \tfrac{1}{2}g^2(T-s)\Delta q_s.$$

检验 $q_s = p_{T-s}$，用 $(\nabla \log p_{T-s})p_{T-s} = \nabla p_{T-s}$，右侧化为

$$\nabla \cdot (\mathbf{f}(\mathbf{x}, T-s)p_{T-s}) - g^2(T-s)\Delta p_{T-s} + \tfrac{1}{2}g^2(T-s)\Delta p_{T-s} = \nabla \cdot (\mathbf{f}p_{T-s}) - \tfrac{1}{2}g^2(T-s)\Delta p_{T-s}.$$

另一方面，正向 FP 与链式法则给出

$$\partial_s p_{T-s} = -\left.\partial_t p_t\right|_{t=T-s} = \nabla \cdot (\mathbf{f}(\mathbf{x}, T-s)p_{T-s}) - \tfrac{1}{2}g^2(T-s)\Delta p_{T-s},$$

恰为逆过程 FP。$q_0 = p_T$ 也相同，因此在 FP 解唯一性条件下，$q_s = p_{T-s}$，返回原时钟即 $\bar{\mathbf{x}}(t) \sim p_t$。所以从 T 向 0 求解逆 SDE，其边缘按逆序沿正向边缘返回。[4] □

[4]译注：证明只验证边缘一致，完整路径反转需更强结果；各 ODE/PDE 唯一性与积分区间正则性须成立，不能只凭局部 C^1 自动推出全局存在/唯一。

D.2.6 命题 4.3.1：SM 与 DSM 的最小化解

证明. 固定 t，考察

$$J(t,\phi) := \mathbb{E}_{\mathbf{x}_0\sim p_{\text{data}}}\mathbb{E}_{\mathbf{x}_t\sim p_t(\cdot|\mathbf{x}_0)}\|\mathbf{s}_\phi(\mathbf{x}_t,t) - \nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)\|_2^2.$$

用联合密度展开即

$$\iint p_{\text{data}}(\mathbf{x}_0)p_t(\mathbf{x}_t\mid\mathbf{x}_0)\|\mathbf{s}_\phi(\mathbf{x}_t,t) - \nabla\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)\|_2^2 d\mathbf{x}_0 d\mathbf{x}_t.$$

固定 $\mathbf{x}_t$ 后，按 Bayes 公式，须最小化

$$\int p(\mathbf{x}_0\mid\mathbf{X}_t=\mathbf{x}_t)p_t(\mathbf{x}_t)\|\mathbf{s}_\phi(\mathbf{x}_t,t) - \nabla\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)\|_2^2 d\mathbf{x}_0.$$

$p_t(\mathbf{x}_t)$ 对预测值为常数，可约去，等价于最小化

$$\int p(\mathbf{x}_0\mid\mathbf{X}_t=\mathbf{x}_t)\|\mathbf{s}_\phi(\mathbf{x}_t,t) - \nabla\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)\|_2^2 d\mathbf{x}_0.$$

平方误差的最优解为条件均值

$$\mathbf{s}^*(\mathbf{x}_t,t) = \mathbb{E}_{\mathbf{X}_0|\mathbf{X}_t=\mathbf{x}_t}[\nabla_{\mathbf{x}_t}\log p_t(\mathbf{x}_t\mid\mathbf{X}_0)].$$

再由边缘 $p_t(\mathbf{x}_t)=\int p_t(\mathbf{x}_t\mid\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0)d\mathbf{x}_0$，在合法交换求导与积分时，

$$\begin{aligned}\nabla\log p_t(\mathbf{x}_t) &= \frac{\int\nabla p_t(\mathbf{x}_t\mid\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0)d\mathbf{x}_0}{\int p_t(\mathbf{x}_t\mid\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0)d\mathbf{x}_0}\\ &= \int p(\mathbf{x}_0\mid\mathbf{x}_t)\nabla\log p_t(\mathbf{x}_t\mid\mathbf{x}_0)d\mathbf{x}_0 = \mathbf{s}^*(\mathbf{x}_t,t).\end{aligned}$$

其中用了 $\nabla p_t(\cdot\mid\mathbf{x}_0)=p_t(\cdot\mid\mathbf{x}_0)\nabla\log p_t(\cdot\mid\mathbf{x}_0)$。证毕。 □

D.2.7 Gaussian 得分的闭式公式

引理 D.2.1 (Gaussian 得分)**.** 对 $\mathbf{x}\in\mathbb{R}^D$，设 $p(\widetilde{\mathbf{x}}\mid\mathbf{x}) := \mathcal{N}(\widetilde{\mathbf{x}};\boldsymbol{\mu},\boldsymbol{\Sigma})$，其中均值 $\boldsymbol{\mu}\in\mathbb{R}^D$、协方差 $\boldsymbol{\Sigma}\in\mathbb{R}^{D\times D}$ 可逆，则

$$\nabla_{\widetilde{\mathbf{x}}}\log p(\widetilde{\mathbf{x}}\mid\mathbf{x}) = -\boldsymbol{\Sigma}^{-1}(\widetilde{\mathbf{x}}-\boldsymbol{\mu}). \tag{D.2.4}$$

证明. Gaussian 密度及其对数为

$$\begin{aligned}p(\widetilde{\mathbf{x}}\mid\mathbf{x}) &= \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}}\exp[-\tfrac{1}{2}(\widetilde{\mathbf{x}}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\widetilde{\mathbf{x}}-\boldsymbol{\mu})],\\ \log p(\widetilde{\mathbf{x}}\mid\mathbf{x}) &= -\tfrac{D}{2}\log(2\pi) - \tfrac{1}{2}\log|\boldsymbol{\Sigma}| - \tfrac{1}{2}(\widetilde{\mathbf{x}}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\widetilde{\mathbf{x}}-\boldsymbol{\mu}).\end{aligned}$$

对 $\widetilde{\mathbf{x}}$ 求梯度，只剩二次型项的 $-1/2$ 倍。协方差对称，故二次型梯度为 $2\boldsymbol{\Sigma}^{-1}(\widetilde{\mathbf{x}}-\boldsymbol{\mu})$，因此

$$\nabla_{\widetilde{\mathbf{x}}}\log p(\widetilde{\mathbf{x}}\mid\mathbf{x}) = -\boldsymbol{\Sigma}^{-1}(\widetilde{\mathbf{x}}-\boldsymbol{\mu}). \tag{D.2.5}$$

□

D.3 流视角

D.3.1 引理 5.1.1：瞬时变量变换

证明. 简记 $p(\mathbf{x}(t),t)=p_t(\mathbf{x}_t)$。

方法 1：变量变换。从 ODE 离散 $\mathbf{z}_{t+\Delta t}=\mathbf{z}_t+\Delta t\mathbf{F}(\mathbf{z}_t,t)$ 出发，归一化流的变量变换式给出

$$\begin{aligned}\log p_{t+\Delta t}(\mathbf{z}_{t+\Delta t}) &= \log p_t(\mathbf{z}_t)-\log|\det(\mathbf{I}+\Delta t\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t))|\\ &= \log p_t(\mathbf{z}_t)-\operatorname{Tr}\log(\mathbf{I}+\Delta t\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t))\\ &= \log p_t(\mathbf{z}_t)-\Delta t\operatorname{Tr}(\nabla_{\mathbf{z}}\mathbf{F}(\mathbf{z}_t,t))+O(\Delta t^2).\end{aligned}$$

这里在足够小步长的适当矩阵对数分支下使用 $\log\det=\operatorname{Tr}\log$。取极限即得对数密度连续时间方程，同一技巧也用于原式 (5.1.6)。

方法 2：连续性方程。作为连续时间变量变换的连续性方程为

$$\partial_t p(\mathbf{z},t)=-\nabla_{\mathbf{z}}\cdot(\mathbf{F}(\mathbf{z},t)p(\mathbf{z},t))=-[(\nabla_{\mathbf{z}}\cdot\mathbf{F})p+\mathbf{F}\cdot\nabla_{\mathbf{z}}p].$$

沿 $d\mathbf{z}/dt=\mathbf{F}$ 的轨迹，

$$\begin{aligned}\frac{d}{dt}p(\mathbf{z}(t),t) &= \nabla_{\mathbf{z}}p\cdot\frac{d\mathbf{z}}{dt}+\partial_t p\\ &= \nabla_{\mathbf{z}}p\cdot\mathbf{F}-[(\nabla_{\mathbf{z}}\cdot\mathbf{F})p+\mathbf{F}\cdot\nabla_{\mathbf{z}}p]=-(\nabla_{\mathbf{z}}\cdot\mathbf{F})p.\end{aligned}$$

除以正密度，得到 $d\log p(\mathbf{z}(t),t)/dt=-\nabla_{\mathbf{z}}\cdot\mathbf{F}(\mathbf{z}(t),t)$。 □

D.3.2 定理 5.2.2：质量守恒判据

预备：流映射及其诱导密度。初态 $\mathbf{x}_0$ 的流是 ODE 唯一解

$$\frac{d}{dt}\Psi_t(\mathbf{x}_0)=\mathbf{v}_t(\Psi_t(\mathbf{x}_0)),\qquad \Psi_0(\mathbf{x}_0)=\mathbf{x}_0.$$

正则假设下，流关于时间、初态连续可微。初始密度 $p_0=p_{\text{data}}$ 的推前为

$$p_t^{\text{fwd}}(\mathbf{x})=p_0(\Psi_t^{-1}(\mathbf{x}))|\det\nabla\Psi_t^{-1}(\mathbf{x})|,$$

即粒子沿 $\mathbf{v}_t$ 运动后的密度。

非正式证明. **源文“充分条件”方向：推前密度相等推出连续性方程**。附录 B.1.2 用变量变换连续极限得到经典强解，要求密度足够光滑、PDE 逐点成立。这里给出弱意义的互补推导：先对任意光滑检验函数积分，降低对密度与速度的正则要求，这是 PDE 和数值分析的标准框架。

任取光滑紧支撑 φ，推前性质与 $\mathbf{x}=\Psi_t(\mathbf{y})$ 的换元给出

$$\begin{aligned}\int p_t^{\text{fwd}}(\mathbf{x})\varphi(\mathbf{x})d\mathbf{x} &= \int p_0(\Psi_t^{-1}(\mathbf{x}))|\det\nabla\Psi_t^{-1}(\mathbf{x})|\varphi(\mathbf{x})d\mathbf{x}\\ &= \int p_0(\mathbf{y})\varphi(\Psi_t(\mathbf{y}))d\mathbf{y}.\end{aligned}$$

两侧对时间求导，左侧为 $\int\partial_t p_t^{\text{fwd}}\varphi\,d\mathbf{x}$；右侧为

$$\int p_0(\mathbf{y})\nabla\varphi(\Psi_t(\mathbf{y}))\cdot\mathbf{v}_t(\Psi_t(\mathbf{y}))d\mathbf{y}.$$

换回 $\mathbf{x}$，用

$$d\mathbf{y} = |\det \nabla \Psi_t^{-1}(\mathbf{x})| d\mathbf{x},$$
$$p_0(\mathbf{y}) = p_t^{\text{fwd}}(\mathbf{x}) |\det \nabla \Psi_t(\mathbf{y})| = \frac{p_t^{\text{fwd}}(\mathbf{x})}{|\det \nabla \Psi_t^{-1}(\mathbf{x})|},$$

右侧化为 $\int p_t^{\text{fwd}} \nabla \varphi \cdot \mathbf{v}_t \, d\mathbf{x}$。紧支撑使积分分部无边界项，故

$$\int p_t^{\text{fwd}} \nabla \varphi \cdot \mathbf{v}_t \, d\mathbf{x} = -\int \varphi \nabla \cdot (p_t^{\text{fwd}} \mathbf{v}_t) d\mathbf{x},$$
$$\int [\partial_t p_t^{\text{fwd}} + \nabla \cdot (p_t^{\text{fwd}} \mathbf{v}_t)] \varphi \, d\mathbf{x} = 0.$$

因此弱意义下 $\partial_t p_t^{\text{fwd}} + \nabla \cdot (p_t^{\text{fwd}} \mathbf{v}_t) = 0$；若 $p_t^{\text{fwd}} = p_t$，目标密度也满足同式。

源文“必要条件”方向：连续性方程推出推前密度相等。若目标 p_t 满足 $\partial_t p_t + \nabla \cdot (p_t \mathbf{v}_t) = 0$，初态 $p_0 = p_{\text{data}}$，而已知 p_t^{fwd} 满足同式，且因 $\Psi_0 = I$ 有 $p_0^{\text{fwd}} = p_0$，两者初始条件相同。展开 PDE 为 $\partial_t p + \mathbf{v}_t \cdot \nabla p + p \nabla \cdot \mathbf{v}_t = 0$。若 $\mathbf{v}_t$ 连续可微且全局 Lipschitz、密度足够光滑，特征线法保证光滑函数空间唯一解，故

$$p_t(\mathbf{x}) = p_t^{\text{fwd}}(\mathbf{x}), \qquad t \in [0,1], \ \mathbf{x} \in \mathbb{R}^D.$$

两方向完成等价性证明。[5] □

D.4 理论补充：统一且系统的扩散模型视角

D.4.1 命题 6.3.1：参数化的等价性

证明. 与得分匹配最优解相同，匹配损失 $\mathbb{E}_t[\omega(t)\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon}}\|\cdot\|_2^2]$ 的理想全局最优在每个固定时刻最小化内部平方误差。标准均方误差的最优预测是条件均值。去噪得分匹配（Vincent, 2011）给出

$$\mathbf{s}^*(\mathbf{x}_t, t) = \mathbb{E}[\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t \mid \mathbf{x}_0) \mid \mathbf{x}_t] = \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t).$$

用条件得分 $-\boldsymbol{\epsilon}/\sigma_t$，得到 $\mathbf{s}^* = -\boldsymbol{\epsilon}^*/\sigma_t$，其中 $\boldsymbol{\epsilon}^* = \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_t]$。干净预测最优为 $\mathbf{x}^* = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_t]$，Tweedie 给出 $\alpha_t \mathbf{x}^* = \mathbf{x}_t + \sigma_t^2 \mathbf{s}^*$。速度最优为

$$\mathbf{v}^* = \mathbb{E}[\alpha_t' \mathbf{x}_0 + \sigma_t' \boldsymbol{\epsilon} \mid \mathbf{x}_t] = \alpha_t' \mathbf{x}^* + \sigma_t' \boldsymbol{\epsilon}^*.$$

代入得

$$\mathbf{v}^*(\mathbf{x}_t, t) = \frac{\alpha_t'}{\alpha_t} \mathbf{x}_t + \left(\frac{\alpha_t'}{\alpha_t} \sigma_t^2 - \sigma_t \sigma_t' \right) \mathbf{s}^*(\mathbf{x}_t, t) = f(t)\mathbf{x}_t - \tfrac{1}{2} g^2(t) \mathbf{s}^*(\mathbf{x}_t, t).$$

[6] □

[5] 译注：源文的“充分/必要”小标题按原样说明方向；两段合起来证明等价，不因其称谓而交换箭头。弱推导不等于任意不正则场的唯一性定理，后半段明确重新使用较强正则条件。

[6] 译注：源文引用“定理 4.3.1”，正文实际标为命题 4.3.1，指向同一最优解。理想逐时最小化须正时间权重与不受限/足够丰富预测类，唯一性是相应测度几乎处处，退化端点的除法另论。

D.5 理论补充：学习快速扩散式生成器

D.5.1 知识蒸馏损失是原式 (10.1.4) 一般框架的实例

先取理想 KD 损失

$$\mathcal{L}_{\mathrm{KD}}^{\mathrm{oracle}}(\theta)=\mathbb{E}_{\mathbf{x}_T\sim p_T}\|G_\theta(\mathbf{x}_T,T,0)-\Psi_{T\to 0}(\mathbf{x}_T)\|_2^2,\qquad p_T=p_{\mathrm{prior}}.$$

确定性 ODE 流满足半群性质、沿轨迹双射，边缘推前关系为

$$p_t=(\Psi_{0\to t})_{\#}p_{\mathrm{data}}=(\Psi_{T\to t})_{\#}p_{\mathrm{prior}}.$$

故

$$(\Psi_{s\to T})_{\#}p_s=p_T,\qquad \Psi_{T\to 0}\circ\Psi_{s\to T}=\Psi_{s\to 0}.$$

以 $\mathbf{x}_T=\Psi_{s\to T}(\mathbf{x}_s)$、$\mathbf{x}_s\sim p_s$ 换元，

$$\mathcal{L}_{\mathrm{KD}}^{\mathrm{oracle}}=\mathbb{E}_{\mathbf{x}_s\sim p_s}\|G_\theta(\Psi_{s\to T}(\mathbf{x}_s),T,0)-\Psi_{s\to 0}(\mathbf{x}_s)\|_2^2.$$

定义拉回学生 $\widetilde{G}_\theta(\mathbf{x}_s,s,0):=G_\theta(\Psi_{s\to T}(\mathbf{x}_s),T,0)$，同一损失便是统一流映射形式在 $t=0$ 的实例：

$$\mathcal{L}_{\mathrm{KD}}^{\mathrm{oracle}}=\mathbb{E}_{\mathbf{x}_s\sim p_s}\|\widetilde{G}_\theta(\mathbf{x}_s,s,0)-\Psi_{s\to 0}(\mathbf{x}_s)\|_2^2.$$

该推导依赖理想流换元与半群性质，不能把实际不可访问的理想回归目标当作已可计算教师。

输运解释。命题 10.2.1 也有分布解释。对 $\widehat{\mathbf{x}}_t=\alpha_t G_\theta(\mathbf{z})+\sigma_t\boldsymbol{\epsilon}$，参数扰动在数据空间诱导位移 $(\partial_\theta\widehat{\mathbf{x}}_t)d\theta$。VSD 梯度可写成

$$\nabla_\theta\mathcal{L}_{\mathrm{VSD}}=\mathbb{E}\left[\omega(t)(\partial_\theta\widehat{\mathbf{x}}_t)^\top(\nabla\log p_t^\theta(\widehat{\mathbf{x}}_t)-\nabla\log p_t(\widehat{\mathbf{x}}_t))\right].$$

得分失配提供数据空间梯度信号，生成器 Jacobian 映回参数空间，梯度下降再沿反方向更新。这是附录 B.3 分布输运观点的参数化对应物。

D.5.2 定理 11.2.1：CM 与 CT 相差至多二阶小量

证明. **步骤 1：理想得分 DDIM 更新等于条件均值**。

$$\begin{aligned}\widehat{\mathbf{x}}_{s'}&:=\frac{\alpha_{s'}}{\alpha_s}\mathbf{x}_s+\sigma_s^2\left(\frac{\alpha_{s'}}{\alpha_s}-\frac{\sigma_{s'}}{\sigma_s}\right)\nabla\log p_s(\mathbf{x}_s)\\&=\frac{\alpha_{s'}}{\alpha_s}(\mathbf{x}_s+\sigma_s^2\nabla\log p_s)-\sigma_{s'}\sigma_s\nabla\log p_s\\&=\alpha_{s'}\mathbb{E}[\mathbf{x}_0\mid\mathbf{x}_s]+\sigma_{s'}\frac{\mathbf{x}_s-\alpha_s\mathbb{E}[\mathbf{x}_0\mid\mathbf{x}_s]}{\sigma_s}\\&=\alpha_{s'}\mathbb{E}[\mathbf{x}_0\mid\mathbf{x}_s]+\sigma_{s'}\mathbb{E}[\boldsymbol{\epsilon}\mid\mathbf{x}_s]=\mathbb{E}[\alpha_{s'}\mathbf{x}_0+\sigma_{s'}\boldsymbol{\epsilon}\mid\mathbf{x}_s]=\mathbb{E}[\mathbf{x}_{s'}\mid\mathbf{x}_s].\end{aligned}$$

第三、四行用 Tweedie $\mathbb{E}[\mathbf{x}_0\mid\mathbf{x}_s]=(\mathbf{x}_s+\sigma_s^2\nabla\log p_s)/\alpha_s$，及共享噪声耦合

$$\mathbf{x}_s=\alpha_s\mathbf{x}_0+\sigma_s\boldsymbol{\epsilon},\qquad \mathbf{x}_{s'}=\alpha_{s'}\mathbf{x}_0+\sigma_{s'}\boldsymbol{\epsilon},\qquad s'=s-\Delta s.$$

更精确地，条件均值应写 $\mathbb{E}[\mathbf{x}_{s'} \mid \mathbf{x}_s, s]$：先抽取 s 后，s' 确定。

步骤 2：围绕条件均值展开 CT。为使长表达清楚，记

$$h(\mathbf{x}') := d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\mathbf{x}', s')),$$
$$\mathbf{A} := \partial_2 d(\mathbf{f}_\theta(\mathbf{x}_s, s), \mathbf{f}_{\theta^-}(\widehat{\mathbf{x}}_{s'}, s'))\, \partial_1 \mathbf{f}_{\theta^-}(\widehat{\mathbf{x}}_{s'}, s').$$

第二式是 h 在 $\widehat{\mathbf{x}}_{s'}$ 处的导数（按源行/列乘积约定）。二阶 Taylor、全期望及条件中心性依次给出

$$\begin{aligned}
\mathcal{L}_{\mathrm{CT}} &= \mathbb{E}_{s,\mathbf{x}_s}\mathbb{E}_{\mathbf{x}_{s'}|\mathbf{x}_s,s}[w(s)h(\mathbf{x}_{s'})] \\
&= \mathbb{E}\mathbb{E}\left[w(s)h(\widehat{\mathbf{x}}_{s'}) + w(s)\mathbf{A}(\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'}) + w(s)O(\|\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'}\|^2)\right] \\
&= \mathbb{E}[w(s)h(\widehat{\mathbf{x}}_{s'})] + \mathbb{E}[w(s)\mathbf{A}\,\mathbb{E}[\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'} \mid \mathbf{x}_s, s]] + \mathbb{E}\mathbb{E}[w(s)O(\|\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'}\|^2)] \\
&= \mathcal{L}_{\mathrm{CM}} + O(\mathbb{E}\|\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'}\|^2) = \mathcal{L}_{\mathrm{CM}} + O(\Delta s^2).
\end{aligned}$$

固定 $(s, \mathbf{x}_s)$ 后，$w(s), \mathbf{f}_\theta(\mathbf{x}_s, s), \widehat{\mathbf{x}}_{s'}, s'$ 均不随内层随机变量变化，唯一一阶随机性来自中心偏差，其条件均值为零。余项中

$$\mathbb{E}\|\mathbf{x}_{s'} - \widehat{\mathbf{x}}_{s'}\|^2 = \mathbb{E}\,\mathrm{Var}(\mathbf{x}_{s'} \mid \mathbf{x}_s, s) \le \mathbb{E}\|\mathbf{x}_{s'} - \mathbf{x}_s\|^2,$$
$$\mathbf{x}_{s'} - \mathbf{x}_s = (\alpha_{s'} - \alpha_s)\mathbf{x}_0 + (\sigma_{s'} - \sigma_s)\boldsymbol{\epsilon}.$$

光滑调度使两系数差为 $O(\Delta s)$，故右侧为 $O(\Delta s^2)$。[7] □

D.5.3 命题 11.3.1：CT 梯度的连续时间极限

证明. 将原式 (11.3.2) 简写为

$$\mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta, \theta^-) := \mathbb{E}\left[\omega(s)\|\mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\Psi_{s\to s-\Delta s}(\mathbf{x}_s), s - \Delta s)\|_2^2\right].$$

记 $\widetilde{\mathbf{x}}_{s-\Delta s} := \Psi_{s\to s-\Delta s}(\mathbf{x}_s)$，$\delta\mathbf{f} := \mathbf{f}_\theta(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\mathbf{x}_s, s)$。平方内差为

$$\delta\mathbf{f} + \mathbf{f}_{\theta^-}(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\widetilde{\mathbf{x}}_{s-\Delta s}, s - \Delta s).$$

理想流的一阶展开及沿轨迹全导数给出

$$\mathbf{x}_s - \Psi_{s\to s-\Delta s}(\mathbf{x}_s) = \mathbf{v}^*(\mathbf{x}_s, s)\Delta s + O(|\Delta s|^2),$$
$$\frac{d}{ds}\mathbf{f}_{\theta^-} = \partial_s \mathbf{f}_{\theta^-} + (\partial_{\mathbf{x}}\mathbf{f}_{\theta^-})\mathbf{v}^*,$$
$$\mathbf{f}_{\theta^-}(\mathbf{x}_s, s) - \mathbf{f}_{\theta^-}(\widetilde{\mathbf{x}}_{s-\Delta s}, s - \Delta s) = \frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\Delta s + O(|\Delta s|^2).$$

所以平方范数展开为

$$\|\delta\mathbf{f}\|_2^2 + 2\delta\mathbf{f}^\top \frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s, s)\Delta s + O(|\Delta s|^2).$$

对 θ 求导，目标 θ^- 视为固定、无梯度，得到

$$\nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\Delta s} = \nabla_\theta \mathbb{E}[\omega(s)\|\delta\mathbf{f}\|_2^2] + 2\mathbb{E}\left[\omega(s)(\nabla_\theta \mathbf{f}_\theta)^\top \frac{d}{ds}\mathbf{f}_{\theta^-}\right]\Delta s + O(|\Delta s|^2).$$

[7] 译注：向量条件方差在此指协方差迹/条件平方范数；二阶余项与期望的阶数交换还需网络/距离导数、权重和数据二阶矩等控制。该结论是损失近似，不是每个有限步样本或两训练过程相同。

在目标为在线网络停止梯度副本的比较点 $\theta=\theta^-$，$\delta\mathbf{f}=0$，第一项梯度为零，因此

$$\nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\Delta s}\big|_{\theta=\theta^-} = 2\,\mathbb{E}\left[\omega(s)(\nabla_\theta \mathbf{f}_\theta)^\top \frac{d}{ds}\mathbf{f}_{\theta^-}\right]\Bigg|_{\theta=\theta^-} \Delta s + O(|\Delta s|^2).$$

除以 Δs 并取极限，

$$\lim_{\Delta s\to 0}\frac{1}{\Delta s}\nabla_\theta \mathcal{L}_{\mathrm{CM}}^{\Delta s}(\theta,\theta^-)\Big|_{\theta=\theta^-} = \nabla_\theta \mathbb{E}\left[2\omega(s)\mathbf{f}_\theta^\top(\mathbf{x}_s,s)\frac{d}{ds}\mathbf{f}_{\theta^-}(\mathbf{x}_s,s)\right]\Bigg|_{\theta=\theta^-}.$$

这证明比较点上的恒等式。平方损失没有 1/2 时保留因子 2，与正文其他约定须相应区分。 □

D.6 （可选）阐明扩散模型（EDM）

这里介绍 Karras et al. (2022) 在 EDM 中提出的干净样本预测网络参数化设计准则。EDM 提供简单配方，使训练更易优化、更可靠：把预测写成时变跳连与缩放残差的组合；在每个时刻将输入和回归目标归一到单位方差，同时调整跳连，使残差误差不随时间被过度放大。这已成为扩散实现中常用默认设计，也自然扩展至流映射学习，尤其一致性模型家族。

D.6.1 神经网络干净预测器的设计准则

EDM 略微滥用记号，把干净预测器记为 $\mathbf{x}_\phi(\mathbf{x},t)$，[8]并取

$$\mathbf{x}_\phi(\mathbf{x},t) := c_{\mathrm{skip}}(t)\mathbf{x} + c_{\mathrm{out}}(t)F_\phi(c_{\mathrm{in}}(t)\mathbf{x}, c_{\mathrm{noise}}(t)). \tag{D.6.1}$$

各系数为时间函数，依据下述实践考虑选择以改善稳定性和性能。代入原式 (6.2.5)，经代数整理得[9]

$$\mathbb{E}_{\mathbf{x}_0,\boldsymbol{\epsilon},t}\left[\omega(t)c_{\mathrm{out}}^2(t)\|F_\phi(c_{\mathrm{in}}(t)\mathbf{x}_t, c_{\mathrm{noise}}(t)) - \mathbf{x}_{\mathrm{tgt}}(t)\|_2^2\right], \tag{D.6.2}$$

其中回归目标

$$\mathbf{x}_{\mathrm{tgt}}(t) = \frac{(1-c_{\mathrm{skip}}(t)\alpha_t)\mathbf{x}_0 - c_{\mathrm{skip}}(t)\sigma_t\boldsymbol{\epsilon}}{c_{\mathrm{out}}(t)}.$$

引入数据标准差 σ_d，单位方差准则如下。

输入单位方差。

$$\begin{aligned}\mathrm{Var}_{\mathbf{x}_0,\boldsymbol{\epsilon}}[c_{\mathrm{in}}(t)\mathbf{x}_t] = 1 &\iff c_{\mathrm{in}}^2(t)\,\mathrm{Var}[\alpha_t\mathbf{x}_0+\sigma_t\boldsymbol{\epsilon}] = 1\\ &\iff c_{\mathrm{in}}(t) = \frac{1}{\sqrt{\sigma_d^2\alpha_t^2+\sigma_t^2}},\end{aligned}$$

取正根。这里方差是源文按单分量/共同标量尺度的约定，不声称一般数据协方差已被完全白化。

[8]前述四种预测类型等价，可化为干净预测。EDM 采用此形式，因为它已有充分研究，也自然贴合流映射生成干净样本的目标；等价所需非退化条件沿用正文。

[9]将式 (D.6.1) 代入干净预测损失：$\mathbb{E}[\omega(t)\|c_{\mathrm{skip}}(\alpha_t\mathbf{x}_0+\sigma_t\boldsymbol{\epsilon}) + c_{\mathrm{out}}F_\phi - \mathbf{x}_0\|_2^2]$，从范数中提取 c_{out}，即为 $\mathbb{E}[\omega(t)c_{\mathrm{out}}^2\|F_\phi - ((1-c_{\mathrm{skip}}\alpha_t)\mathbf{x}_0 - c_{\mathrm{skip}}\sigma_t\boldsymbol{\epsilon})/c_{\mathrm{out}}\|_2^2]$，得到式 (D.6.2)；此处 F_ϕ 的输入沿正文。

训练目标单位方差。中心化数据 $\mathbb{E}\mathbf{x}_0 = 0$ 下，

$$\mathrm{Var}[\mathbf{x}_{\mathrm{tgt}}(t)] = 1 \quad \Longleftrightarrow \quad c_{\mathrm{out}}^2(t) = (1 - c_{\mathrm{skip}}(t)\alpha_t)^2\sigma_d^2 + c_{\mathrm{skip}}^2(t)\sigma_t^2. \tag{D.6.3}$$

最小化从残差网络到预测器的误差放大。选择 $c_{\mathrm{skip}}^* \in \arg\min_{c_{\mathrm{skip}}} c_{\mathrm{out}}^2$。源文以 $\partial c_{\mathrm{out}}/\partial c_{\mathrm{skip}} = 0$ 表述求临界点；在取正输出尺度的内部，这等价于对上述平方二次式求导。由此得到

$$c_{\mathrm{skip}}^*(t) = \frac{\alpha_t\sigma_d^2}{\alpha_t^2\sigma_d^2 + \sigma_t^2}, \qquad c_{\mathrm{out}}^*(t) = \pm\frac{\sigma_t\sigma_d}{\sqrt{\alpha_t^2\sigma_d^2 + \sigma_t^2}}.$$

按约定取非负分支。原文据此说明 $c_{\mathrm{out}}(0) = 0$，噪声足够大时趋于 σ_d，从而 $\mathbf{x}_\phi(\mathbf{x}_t, 0) \approx \mathbf{x}_t$，高噪时约为 $\sigma_d F_\phi$；这些极限依赖下述起终调度条件。记 $R_t := \alpha_t^2\sigma_d^2 + \sigma_t^2$，汇总为

$$c_{\mathrm{in}}(t) = \frac{1}{\sqrt{R_t}}, \qquad c_{\mathrm{skip}}(t) = \frac{\alpha_t\sigma_d^2}{R_t}, \qquad c_{\mathrm{out}}(t) = \frac{\sigma_t\sigma_d}{\sqrt{R_t}}. \tag{D.6.4}$$

目标简化为 $\mathbf{x}_{\mathrm{tgt}} = (\sigma_t\mathbf{x}_0 - \alpha_t\sigma_d^2\boldsymbol{\epsilon})/(\sigma_d\sqrt{R_t})$，参数化与损失分别为

$$\mathbf{x}_\phi(\mathbf{x}, t) = \frac{\alpha_t\sigma_d^2}{R_t}\mathbf{x} + \frac{\sigma_t\sigma_d}{\sqrt{R_t}}F_\phi\left(\frac{\mathbf{x}}{\sqrt{R_t}}, c_{\mathrm{noise}}(t)\right),$$
$$\mathcal{L} = \mathbb{E}\left[\omega(t)\frac{\sigma_t^2}{R_t}\left\|\sigma_d F_\phi\left(\frac{\mathbf{x}_t}{\sqrt{R_t}}, c_{\mathrm{noise}}(t)\right) - \frac{\sigma_t\mathbf{x}_0 - \alpha_t\sigma_d^2\boldsymbol{\epsilon}}{\sqrt{R_t}}\right\|_2^2\right].$$

若 $\alpha_0 \approx 1$、$\sigma_0 \approx 0$，则 $c_{\mathrm{skip}}(0) \approx 1$、$c_{\mathrm{out}}(0) \approx 0$。[10]

选择噪声嵌入。c_{noise} 向网络提供噪声层级，任何噪声水平的一一映射都可，例如 $\log\sigma_t$；零噪端点需单独处理对数定义。

D.6.2 常见 EDM 特例：单位信号系数、线性噪声尺度

取 $\alpha_t = 1$、$\sigma_t = t$，即第 11.4 节 CTM 也采用的简化调度。正向过程为 $\mathbf{x}_t = \mathbf{x}_0 + t\boldsymbol{\epsilon}$，$\mathbf{x}_0 \sim p_{\mathrm{data}}$、$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，扰动核为 $\mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, t^2\mathbf{I})$。边缘为

$$p_t(\mathbf{x}) = \int \mathcal{N}(\mathbf{x}; \mathbf{x}_0, t^2\mathbf{I})p_{\mathrm{data}}(\mathbf{x}_0)d\mathbf{x}_0 = [p_{\mathrm{data}} * \mathcal{N}(\mathbf{0}, t^2\mathbf{I})](\mathbf{x}).$$

精确终端为数据与 Gaussian 的卷积。当 T 相对数据尺度足够大时，常用 $\mathcal{N}(\mathbf{0}, T^2\mathbf{I})$ 近似，并将其设为采样先验 $p_{\mathrm{prior}}(\mathbf{x}_T)$；两者并非一般精确相等。

基于干净预测的 PF-ODE（原式 6.3.2）化为

$$\frac{d\mathbf{x}(t)}{dt} = \frac{\mathbf{x}(t) - \mathbf{x}_{\phi^\times}(\mathbf{x}(t), t)}{t}.$$

神经参数化系数变为

$$c_{\mathrm{in}}(t) = \frac{1}{\sqrt{\sigma_d^2 + t^2}}, \quad c_{\mathrm{skip}}(t) = \frac{\sigma_d^2}{\sigma_d^2 + t^2}, \quad c_{\mathrm{out}}(t) = \pm\frac{t\sigma_d}{\sqrt{\sigma_d^2 + t^2}}. \tag{D.6.5}$$

此式按源保留 $\pm$；前文约定采用正分支，负分支需连同网络目标符号一致改变。

[10]译注：目标除以 c_{out} 的表达在零噪端点需用极限或不取该端点；不能把 0/0 当作普通目标。高噪极限须 σ_t^2 支配 $\alpha_t^2\sigma_d^2$，不是任意调度下仅有“t 大”即成立。

- $t \approx 0$，噪声可忽略，跳连约 1、输出尺度约 0，模型基本透传输入：$\mathbf{x}_\phi(\mathbf{x}, t) \approx \mathbf{x}$。
- 高噪时（源文写作 $t \gg 0$；此处尺度条件为 $t \gg \sigma_d$），跳连约 0、输出尺度约 σ_d，输出由学习残差决定：

$$\mathbf{x}_\phi(\mathbf{x}, t) \approx \sigma_d F_\phi(c_{\text{in}}(t)\mathbf{x}, c_{\text{noise}}(t)).$$

  网络从归一化含噪输入预测干净信号的缩放代理。

该参数化在低噪的恒等映射与高噪的标准化输入残差预测之间平滑插值。

参考文献

译本说明：以下完整保留冻结 v3 的参考文献表，书目题名与出版信息使用原文。正文中源版本已显示为未解析引文键的项目仍按源保留，未依据新版或记忆补造；原表中的重复作者、年份、大小写和重复版本不擅改。此表不表示已逐条向外部数据库核验。

Ackley, D. H., G. E. Hinton, and T. J. Sejnowski. (1985). “A learning algorithm for Boltzmann machines”. Cognitive science. 9(1): 147–169.

Albergo, M. S., N. M. Boffi, and E. Vanden-Eijnden. (2023). “Stochastic interpolants: A unifying framework for flows and diffusions”. arXiv preprint arXiv:2303.08797.

Albergo, M. S. and E. Vanden-Eijnden. (2023). “Building Normalizing Flows with Stochastic Interpolants”. In: The Eleventh International Conference on Learning Representations.

Altschuler, J., J. Niles-Weed, and P. Rigollet. (2017). “Near-linear time approximation algorithms for optimal transport via Sinkhorn iteration”. Advances in neural information processing systems. 30.

Anderson, B. D. (1982). “Reverse-time diffusion equation models”. Stochastic Processes and their Applications. 12(3): 313–326.

Atkinson, K., W. Han, and D. E. Stewart. (2009). Numerical solution of ordinary differential equations. Vol. 81. John Wiley & Sons.

Bansal, A., H.-M. Chu, A. Schwarzschild, S. Sengupta, M. Goldblum, J. Geiping, and T. Goldstein. (2023). “Universal guidance for diffusion models”. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 843–852.

Behrmann, J., W. Grathwohl, R. T. Chen, D. Duvenaud, and J.-H. Jacobsen. (2019). “Invertible residual networks”. In: International conference on machine learning. PMLR. 573–582.

Benamou, J.-D. and Y. Brenier. (2000). “A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem”. Numerische Mathematik. 84(3): 375–393.

Boffi, N. M., M. S. Albergo, and E. Vanden-Eijnden. (2024). “Flow Map Matching”. arXiv preprint arXiv:2406.07507.

Bradley, R. A. and M. E. Terry. (1952). “Rank analysis of incomplete block designs: I. the method of paired comparisons”. Biometrika. 39(3/4): 324–345.

Caluya, K. F. and A. Halder. (2021). “Wasserstein proximal algorithms for the Schrödinger bridge problem: Density control with nonlinear drift”. IEEE Transactions on Automatic Control. 67(3): 1163–1178.

Chen, R. T., J. Behrmann, D. K. Duvenaud, and J.-H. Jacobsen. (2019). “Residual flows for invertible generative modeling”. Advances in Neural Information Processing Systems. 32.

Chen, R. T., Y. Rubanova, J. Bettencourt, and D. K. Duvenaud. (2018). “Neural ordinary differential equations”. Advances in neural information processing systems. 31.

Chen, T., G.-H. Liu, and E. Theodorou. (2022). “Likelihood Training of Schrödinger Bridge using Forward-Backward SDEs Theory”. In: International Conference on Learning Representations.

Chen, Y., T. T. Georgiou, and M. Pavon. (2016). “On the relation between optimal transport and Schrödinger bridges: A stochastic control viewpoint”. Journal of Optimization Theory and Applications. 169: 671–691.

Chen, Y., T. T. Georgiou, and M. Pavon. (2021). “Stochastic control liaisons: Richard sinkhorn meets gaspard monge on a schrodinger bridge”. Siam Review. 63(2): 249–313.

Choi, J., S. Kim, Y. Jeong, Y. Gwon, and S. Yoon. (2021). “ILVR: Conditioning Method for Denoising Diffusion Probabilistic Models”. In: 2021 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE. 14347–14356.

Chung, H., J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye. (2022). “Diffusion posterior sampling for general noisy inverse problems”. arXiv preprint arXiv:2209.14687.

Chung, H., J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye. (2023). “Diffusion Posterior Sampling for General Noisy Inverse Problems”. In: The Eleventh International Conference on Learning Representations. url: https://openreview.net/forum?id=OnD9zGAGT0k.

Csiszár, I. (1963). “Eine informationstheoretische Ungleichung und ihre Anwendung auf den Beweis der Ergodizität von Markoffschen Ketten”. A Magyar Tudományos Akadémia Matematikai Kutató Intézetének Közleményei. 8(1-2): 85–108.

Cuturi, M. (2013). “Sinkhorn distances: Lightspeed computation of optimal transport”. Advances in neural information processing systems. 26.

Dai Pra, P. (1991). “A stochastic control approach to reciprocal diffusion processes”. Applied mathematics and Optimization. 23(1): 313–329.

Daras, G., H. Chung, C.-H. Lai, Y. Mitsufuji, J. C. Ye, P. Milanfar, A. G. Dimakis, and M. Delbracio. (2024). “A survey on diffusion models for inverse problems”. arXiv preprint arXiv:2410.00083.

Daras, G., Y. Dagan, A. Dimakis, and C. Daskalakis. (2023). “Consistent diffusion models: Mitigating sampling drift by learning to be consistent”. Advances in Neural Information Processing Systems. 36: 42038–42063.

De Bortoli, V. (2022). “Convergence of denoising diffusion models under the manifold hypothesis”. arXiv preprint arXiv:2208.05314.

De Bortoli, V., J. Thornton, J. Heng, and A. Doucet. (2021). “Diffusion schrödinger bridge with applications to score-based generative modeling”. Advances in Neural Information Processing Systems. 34: 17695–17709.

Dhariwal, P. and A. Nichol. (2021). “Diffusion models beat gans on image synthesis”. Advances in Neural Information Processing Systems. 34: 8780–8794.

Efron, B. (2011). “Tweedie’s formula and selection bias”. Journal of the American Statistical Association. 106(496): 1602–1614.

Esser, P., S. Kulal, A. Blattmann, R. Entezari, J. Müller, H. Saini, Y. Levi, D. Lorenz, A. Sauer, F. Boesel, et al. (2024). “Scaling rectified flow transformers for high-resolution image synthesis”. In: Forty-first International Conference on Machine Learning.

Evans, L. C. (2010). Partial differential equations. Providence, R.I.: American Mathematical Society.

Fournier, N. and A. Guillin. (2015). “On the rate of convergence in Wasserstein distance of the empirical measure”. Probability theory and related fields. 162(3): 707–738.

Frey, B. J., G. E. Hinton, and P. Dayan. (1995). “Does the wake-sleep algorithm produce good density estimators?” Advances in neural information processing systems. 8.

Genevay, A., G. Peyré, and M. Cuturi. (2018). “Learning generative models with sinkhorn divergences”. In: International Conference on Artificial Intelligence and Statistics. PMLR. 1608–1617.

Geng, Z., M. Deng, X. Bai, J. Z. Kolter, and K. He. (2025a). “Mean flows for one-step generative modeling”. arXiv preprint arXiv:2505.13447.

Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter. (2025b). “Consistency Models Made Easy”. In: The Thirteenth International Conference on Learning Representations. url: https://openreview.net/forum?id=xQVxo9dSID.

Geng, Z., A. Pokle, W. Luo, J. Lin, and J. Z. Kolter. (2024). “Consistency models made easy”. arXiv preprint arXiv:2406.14548.

Goodfellow, I., J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. (2014). “Generative adversarial nets”. Advances in neural information processing systems. 27.

He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, et al. (2023). “Manifold preserving guided diffusion”. In: International Conference on Learning Representations.

He, Y., N. Murata, C.-H. Lai, Y. Takida, T. Uesaka, D. Kim, W.-H. Liao, Y. Mitsufuji, J. Z. Kolter, R. Salakhutdinov, and S. Ermon. (2024). “Manifold Preserving Guided Diffusion”. In: The Twelfth International Conference on Learning Representations. url: https://openreview.net/forum?id=o3BxOLoxm1.

Heitz, E., L. Belcour, and T. Chambon. (2023). “Iterative α-(de) blending: A minimalist deterministic diffusion model”. In: ACM SIGGRAPH 2023 Conference Proceedings. 1–8.

Hertrich, J., A. Chambolle, and J. Delon. (2025). “On the Relation between Rectified Flows and Optimal Transport”. arXiv preprint arXiv:2505.19712.

Hinton, G. E. (2002). “Training products of experts by minimizing contrastive divergence”. Neural computation. 14(8): 1771–1800.

Ho, J., A. Jain, and P. Abbeel. (2020). “Denoising diffusion probabilistic models”. Advances in Neural Information Processing Systems. 33: 6840–6851.

Ho, J. and T. Salimans. (2021). “Classifier-Free Diffusion Guidance”. In: NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications.

Hochbruck, M. and A. Ostermann. (2005). “Explicit exponential Runge–Kutta methods for semilinear parabolic problems”. SIAM Journal on Numerical Analysis. 43(3): 1069–1090.

Hochbruck, M. and A. Ostermann. (2010). “Exponential integrators”. Acta Numerica. 19: 209–286.

Hu, Z., C.-H. Lai, Y. Mitsufuji, and S. Ermon. (2025). “CMT: Mid-Training for Efficient Learning of Consistency, Mean Flow, and Flow Map Models”. arXiv preprint arXiv:2509.24526.

Huang, C.-W., R. T. Chen, C. Tsirigotis, and A. Courville. (2021). “Convex Potential Flows: Universal Probability Distributions with Optimal Transport and Convex Optimization”. In: International Conference on Learning Representations.

Hutchinson, M. F. (1989). “A stochastic estimator of the trace of the influence matrix for Laplacian smoothing splines”. Communications in Statistics-Simulation and Computation.

18(3): 1059–1076.

Hyvärinen, A. and P. Dayan. (2005). “Estimation of non-normalized statistical models by score matching.” Journal of Machine Learning Research. 6(4).

Iserles, A. (2009). A first course in the numerical analysis of differential equations. No. 44. Cambridge university press.

Karras, T., M. Aittala, T. Aila, and S. Laine. (2022). “Elucidating the design space of diffusion-based generative models”. Advances in Neural Information Processing Systems. 35: 26565–26577.

Karras, T., M. Aittala, J. Lehtinen, J. Hellsten, T. Aila, and S. Laine. (2023). “Analyzing and improving the training dynamics of diffusion models”. arXiv preprint arXiv:2312.02696.

Karras, T., M. Aittala, J. Lehtinen, J. Hellsten, T. Aila, and S. Laine. (2024). “Analyzing and Improving the Training Dynamics of Diffusion Models”. In: IEEE Conference on Computer Vision and Pattern Recognition. IEEE. 24174–24184.

Kim, D., C.-H. Lai, W.-H. Liao, N. Murata, Y. Takida, T. Uesaka, Y. He, Y. Mitsufuji, and S. Ermon. (2024a). “Consistency trajectory models: Learning probability flow ode trajectory of diffusion”. In: International Conference on Learning Representations.

Kim, D., C.-H. Lai, W.-H. Liao, Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon. (2024b). “PaGoDA: Progressive Growing of a One-Step Generator from a Low-Resolution Diffusion Teacher”. arXiv preprint arXiv:2405.14822.

Kim, D., S. Shin, K. Song, W. Kang, and I.-C. Moon. (2022). “Soft truncation: A universal training technique of score-based diffusion model for high precision score estimation”. In: International Conference on Machine Learning. PMLR. 11201–11228.

Kingma, D., T. Salimans, B. Poole, and J. Ho. (2021). “Variational diffusion models”. Advances in neural information processing systems. 34: 21696–21707.

Kingma, D. P. and R. Gao. (2023). “Understanding Diffusion Objectives as the ELBO with Simple Data Augmentation”. In: Thirty-seventh Conference on Neural Information Processing Systems.

Kingma, D. P. and M. Welling. (2013). “Auto-encoding variational bayes”. arXiv preprint arXiv:1312.6114.

Kloeden, P. E., E. Platen, P. E. Kloeden, and E. Platen. (1992). Stochastic differential equations. Springer.

Lai, C.-H., Y. Takida, N. Murata, T. Uesaka, Y. Mitsufuji, and S. Ermon. (2023a). “FP-Diffusion: Improving score-based diffusion models by enforcing the underlying score fokker-

planck equation". In: International Conference on Machine Learning. PMLR. 18365–18398.

Lai, C.-H., Y. Takida, T. Uesaka, N. Murata, Y. Mitsufuji, and S. Ermon. (2023b). "On the Equivalence of Consistency-Type Models: Consistency Models, Consistent Diffusion Models, and Fokker-Planck Regularization". arXiv preprint arXiv:2306.00367.

Larochelle, H. and I. Murray. (2011). "The neural autoregressive distribution estimator". In: Proceedings of the fourteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings. 29–37.

Lavenant, H. and F. Santambrogio. (2022). "The flow map of the fokker–planck equation does not provide optimal transport". Applied Mathematics Letters. 133: 108225.

LeCun, Y., S. Chopra, R. Hadsell, M. Ranzato, F. Huang, et al. (2006). "A tutorial on energy-based learning". Predicting structured data. 1(0).

Léonard, C. (2012). "From the Schrödinger problem to the Monge–Kantorovich problem". Journal of Functional Analysis. 262(4): 1879–1920.

Léonard, C. (2014). "A survey of the Schrödinger problem and some of its connections with optimal transport". Discrete and Continuous Dynamical Systems-Series A. 34(4): 1533–1574.

Lipman, Y., R. T. Chen, H. Ben-Hamu, M. Nickel, and M. Le. (2022). "Flow Matching for Generative Modeling". In: The Eleventh International Conference on Learning Representations.

Lipman, Y., M. Havasi, P. Holderrieth, N. Shaul, M. Le, B. Karrer, R. T. Chen, D. Lopez-Paz, H. Ben-Hamu, and I. Gat. (2024). "Flow matching guide and code". arXiv preprint arXiv:2412.06264.

Liu, G.-H., A. Vahdat, D.-A. Huang, E. Theodorou, W. Nie, and A. Anandkumar. (2023). "I^2SB: Image-to-Image Schrödinger Bridge". In: International Conference on Machine Learning. PMLR. 22042–22062.

Liu, Q. (2022). "Rectified flow: A marginal preserving approach to optimal transport". arXiv preprint arXiv:2209.14577.

Liu, X., C. Gong, et al. (2022). "Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow". In: The Eleventh International Conference on Learning Representations.

Lou, A., C. Meng, and S. Ermon. (2024). "Discrete Diffusion Modeling by Estimating the Ratios of the Data Distribution". In: International Conference on Machine Learning. PMLR. 32819–32848.

Lu, C. and Y. Song. (2024). “Simplifying, stabilizing and scaling continuous-time consistency models”. arXiv preprint arXiv:2410.11081.

Lu, C., K. Zheng, F. Bao, J. Chen, C. Li, and J. Zhu. (2022a). “Maximum Likelihood Training for Score-based Diffusion ODEs by High Order Denoising Score Matching”. In: International Conference on Machine Learning. PMLR. 14429–14460.

Lu, C., Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu. (2022b). “Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps”. Advances in Neural Information Processing Systems. 35: 5775–5787.

Lu, C., Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu. (2022c). “Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models”. arXiv preprint arXiv:2211.01095.

Luan, V. T. (2021). “Efficient exponential Runge–Kutta methods of high order: construction and implementation”. BIT Numerical Mathematics. 61(2): 535–560.

Luhman, E. and T. Luhman. (2021). “Knowledge distillation in iterative generative models for improved sampling speed”. arXiv preprint arXiv:2101.02388.

Luo, W., T. Hu, S. Zhang, J. Sun, Z. Li, and Z. Zhang. (2023). “Diff-instruct: A universal approach for transferring knowledge from pre-trained diffusion models”. Advances in Neural Information Processing Systems. 36: 76525–76546.

Ma, N., M. Goldstein, M. S. Albergo, N. M. Boffi, E. Vanden-Eijnden, and S. Xie. (2024). “Sit: Exploring flow and diffusion-based generative models with scalable interpolant transformers”. In: European Conference on Computer Vision. Springer. 23–40.

Maoutsa, D., S. Reich, and M. Opper. (2020). “Interacting particle solutions of fokker–planck equations through gradient–log–density estimation”. Entropy. 22(8): 802.

Meng, C., K. Choi, J. Song, and S. Ermon. (2022). “Concrete score matching: Generalized score matching for discrete data”. Advances in Neural Information Processing Systems. 35: 34532–34545.

Meng, C., R. Rombach, R. Gao, D. Kingma, S. Ermon, J. Ho, and T. Salimans. (2023). “On distillation of guided diffusion models”. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 14297–14306.

Meng, C., Y. Song, W. Li, and S. Ermon. (2021a). “Estimating high order gradients of the data distribution by denoising”. Advances in Neural Information Processing Systems. 34: 25359–25369.

Meng, C., Y. Song, J. Song, J. Wu, J.-Y. Zhu, and S. Ermon. (2021b). “Sdedit: Image synthesis and editing with stochastic differential equations”. arXiv preprint arXiv:2108.01073.

Mikami, T. and M. Thieullen. (2006). “Duality theorem for the stochastic optimal control problem”. Stochastic processes and their applications. 116(12): 1815–1835.

Mikami, T. and M. Thieullen. (2008). “Optimal transportation problem by stochastic optimal control”. SIAM Journal on Control and Optimization. 47(3): 1127–1139.

Mokady, R., A. Hertz, K. Aberman, Y. Pritch, and D. Cohen-Or. (2023). “Null-text inversion for editing real images using guided diffusion models”. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 6038–6047.

Neklyudov, K., R. Brekelmans, D. Severo, and A. Makhzani. (2023). “Action matching: Learning stochastic dynamics from samples”. In: International Conference on Machine Learning. PMLR. 25858–25889.

Nowozin, S., B. Cseke, and R. Tomioka. (2016). “f-gan: Training generative neural samplers using variational divergence minimization”. Advances in neural information processing systems. 29.

Øksendal, B. (2003). “Stochastic differential equations”. In: Stochastic differential equations. Springer. 65–84.

Onken, D., S. W. Fung, X. Li, and L. Ruthotto. (2021). “Ot-flow: Fast and accurate continuous normalizing flows via optimal transport”. In: Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 35. No. 10. 9223–9232.

Pavon, M. and A. Wakolbinger. (1991). “On free energy, stochastic control, and Schrödinger processes”. In: Modeling, Estimation and Control of Systems with Uncertainty: Proceedings of a Conference held in Sopron, Hungary, September 1990. Springer. 334–348.

Peters, J., K. Mulling, and Y. Altun. (2010). “Relative entropy policy search”. In: Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 24. No. 1. 1607–1612.

Peyré, G., M. Cuturi, et al. (2019). “Computational optimal transport: With applications to data science”. Foundations and Trends® in Machine Learning. 11(5-6): 355–607.

Pontryagin, L. S. (2018). Mathematical theory of optimal processes. Routledge.

Poole, B., A. Jain, J. T. Barron, and B. Mildenhall. (2023). “DreamFusion: Text-to-3D using 2D Diffusion”. In: The Eleventh International Conference on Learning Representations.

Pra, P. D. and M. Pavon. (1990). “On the Markov processes of Schrödinger, the Feynman-Kac formula and stochastic control”. In: Realization and Modelling in System Theory: Proceedings of the International Symposium MTNS-89, Volume I. Springer. 497–504.

Radford, A., J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. (2021). “Learning transferable visual models from natural language

supervision". In: International conference on machine learning. PMLR. 8748–8763.

Rafailov, R., A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, and C. Finn. (2023). "Direct preference optimization: Your language model is secretly a reward model". Advances in neural information processing systems. 36: 53728–53741.

Raissi, M. (2018). "Deep hidden physics models: Deep learning of nonlinear partial differential equations". Journal of Machine Learning Research. 19(25): 1–24.

Reid, W. (1971). Ordinary Differential Equations. Applied mathematics series. Wiley.

Rezende, D. and S. Mohamed. (2015). "Variational inference with normalizing flows". In: International conference on machine learning. PMLR. 1530–1538.

Saharia, C., W. Chan, S. Saxena, L. Li, J. Whang, E. L. Denton, K. Ghasemipour, R. Gontijo Lopes, B. Karagol Ayan, T. Salimans, et al. (2022). "Photorealistic text-to-image diffusion models with deep language understanding". Advances in Neural Information Processing Systems. 35: 36479–36494.

Salimans, T. and J. Ho. (2021). "Progressive Distillation for Fast Sampling of Diffusion Models". In: International Conference on Learning Representations.

Särkkä, S. and A. Solin. (2019). Applied stochastic differential equations. Vol. 10. Cambridge University Press.

Schulman, J., F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. (2017). "Proximal policy optimization algorithms". arXiv preprint arXiv:1707.06347.

Shih, A., S. Belkhale, S. Ermon, D. Sadigh, and N. Anari. (2023). "Parallel Sampling of Diffusion Models". arXiv preprint arXiv:2305.16317.

Sinkhorn, R. (1964). "A relationship between arbitrary positive matrices and doubly stochastic matrices". The annals of mathematical statistics. 35(2): 876–879.

Sohl-Dickstein, J., E. Weiss, N. Maheswaranathan, and S. Ganguli. (2015). "Deep unsupervised learning using nonequilibrium thermodynamics". In: International Conference on Machine Learning. PMLR. 2256–2265.

Song, J., C. Meng, and S. Ermon. (2020a). "Denoising Diffusion Implicit Models". In: International Conference on Learning Representations.

Song, Y. and P. Dhariwal. (2024). "Improved Techniques for Training Consistency Models". In: The Twelfth International Conference on Learning Representations.

Song, Y., P. Dhariwal, M. Chen, and I. Sutskever. (2023). "Consistency models". arXiv preprint arXiv:2303.01469.

Song, Y., C. Durkan, I. Murray, and S. Ermon. (2021). “Maximum likelihood training of score-based diffusion models”. Advances in Neural Information Processing Systems. 34: 1415–1428.

Song, Y. and S. Ermon. (2019). “Generative modeling by estimating gradients of the data distribution”. Advances in Neural Information Processing Systems. 32.

Song, Y., S. Garg, J. Shi, and S. Ermon. (2020b). “Sliced score matching: A scalable approach to density and score estimation”. In: Uncertainty in Artificial Intelligence. PMLR. 574–584.

Song, Y., J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole. (2020c). “Score-Based Generative Modeling through Stochastic Differential Equations”. In: International Conference on Learning Representations.

Su, X., J. Song, C. Meng, and S. Ermon. (2022). “Dual diffusion implicit bridges for image-to-image translation”. arXiv preprint arXiv:2203.08382.

Tabak, E. G. and E. Vanden-Eijnden. (2010). “Density estimation by dual ascent of the log-likelihood”. Commun. Math. Sci. 8(1): 217–233.

Tong, A., K. FATRAS, N. Malkin, G. Huguet, Y. Zhang, J. Rector-Brooks, G. Wolf, and Y. Bengio. (2024). “Improving and generalizing flow-based generative models with minibatch optimal transport”. Transactions on Machine Learning Research.

Turner, C. V. (2013). “A family of nonparametric density estimation algorithms”. Communications on Pure and Applied Mathematics. 66(2): 145–164.

Uria, B., M.-A. Côté, K. Gregor, I. Murray, and H. Larochelle. (2016). “Neural autoregressive distribution estimation”. Journal of Machine Learning Research. 17(205): 1–37.

Vahdat, A. and J. Kautz. (2020). “NVAE: A deep hierarchical variational autoencoder”. Advances in neural information processing systems. 33: 19667–19679.

Villani, C. et al. (2008). Optimal transport: old and new. Vol. 338. Springer.

Vincent, P. (2011). “A connection between score matching and denoising autoencoders”. Neural computation. 23(7): 1661–1674.

Wallace, B., M. Dang, R. Rafailov, L. Zhou, A. Lou, S. Purushwalkam, S. Ermon, C. Xiong, S. Joty, and N. Naik. (2024). “Diffusion model alignment using direct preference optimization”. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 8228–8238.

Wang, Z., C. Lu, Y. Wang, F. Bao, C. Li, H. Su, and J. Zhu. (2023). “Prolificdreamer: High-fidelity and diverse text-to-3d generation with variational score distillation”. Advances in Neural Information Processing Systems. 36: 8406–8441.

Xu, Y., M. Deng, X. Cheng, Y. Tian, Z. Liu, and T. S. Jaakkola. (2023). “Restart Sampling for Improving Generative Processes”. In: Thirty-seventh Conference on Neural Information Processing Systems. url: https://openreview.net/forum?id=wFuemocyHZ.

Ye, H., H. Lin, J. Han, M. Xu, S. Liu, Y. Liang, J. Ma, J. Y. Zou, and S. Ermon. (2024). “Tfg: Unified training-free guidance for diffusion models”. Advances in Neural Information Processing Systems. 37: 22370–22417.

Yin, T., M. Gharbi, T. Park, R. Zhang, E. Shechtman, F. Durand, and B. Freeman. (2024a). “Improved distribution matching distillation for fast image synthesis”. Advances in neural information processing systems. 37: 47455–47487.

Yin, T., M. Gharbi, R. Zhang, E. Shechtman, F. Durand, W. T. Freeman, and T. Park. (2024b). “One-Step Diffusion with Distribution Matching Distillation”. In: 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE. 6613–6623.

Yu, J., Y. Wang, C. Zhao, B. Ghanem, and J. Zhang. (2023). “Freedom: Training-free energy-guided conditional diffusion model”. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. 23174–23184.

Zhang, Q. and Y. Chen. (2022). “Fast Sampling of Diffusion Models with Exponential Integrator”. In: The Eleventh International Conference on Learning Representations.

Zheng, K., C. Lu, J. Chen, and J. Zhu. (2023). “Dpm-solver-v3: Improved diffusion ode solver with empirical model statistics”. Advances in Neural Information Processing Systems. 36: 55502–55542.

Zhou, M., H. Zheng, Z. Wang, M. Yin, and H. Huang. (2024). “Score identity distillation: Exponentially fast distillation of pretrained diffusion models for one-step generation”. In: Forty-first International Conference on Machine Learning.