
深度学习理论原理

理解神经网络的有效理论方法

The Principles of Deep Learning Theory

Daniel A. Roberts, Sho Yaida

arXiv v2 · arXiv:2106.10165 · 2021

Model: OpenAI GPT-5.6 Sol

审核: 曹溪能

Updated: 31 Aug 2026

第 1 章

序言

这就要求我们同历史上的发展脉络彻底决裂；不过，这种决裂反而是一项优势，因为它使我们能够尽可能直接地切入新思想。

P. A. M. 狄拉克,《量子力学原理》
1930 年版序言 [1].

这是一本以教科书风格写成、讨论深度学习理论的研究专著。本书看起来也许与你以往见过的深度学习书籍有些不同，但我们向你保证：只要具备线性代数、多元微积分和非形式化概率论知识，并对神经网络怀有浓厚兴趣，本书就适合你。无论你是实践者还是理论研究者，我们都希望你能享受阅读本书的过程。现在，让我们先说明几件事。

首先，在本书的每一项取舍中，我们都力求有助于教学，并把直觉置于形式化之上。这并不意味着计算不完整或草率；恰恰相反，我们尽力给出每一步计算的全部细节——而这样的计算确实非常多——并特别强调完成相关计算所需的工具。事实上，理解计算是怎样做出的，与知道计算结果同等重要，因此我们的教学重点往往就在这些细节之中。

其次，虽然我们给出了所有计算的细节，但实验验证仍留在我们私有的计算机笔记本中。理由很简单：解释一项推导可以让人学到许多东西，而打印一张显示两条曲线彼此重合的验证图，能带来的新知识却十分有限。得益于现代深度学习代码的简洁以及算力的普及，你很容易自行验证任何公式；我们当然已经用这种方式彻底检查过所有公式。因而，如果知道这些图确实存在能让你安心，那么至少可以确信：它们确实存放在我们的个人硬盘和云端硬盘上。

第三，我们主要关注深度学习共同体在实践中使用的现实模型：我们要研究的是深神经网络。具体而言，这意味着 (i) 我们不会讨论若干只适用于单隐层网络的特殊结果；(ii) 神经网络的无限宽极限——它对应于零隐层网络——只会作为起点引入。所有这类理想化模型最终都会受到扰动，直至与真实模型相对应。我们当然承认，有一个充满活力的深度学习理论共同体正致力于探索各种理想化的理论极限。不过，我们始终关心的是解释实践者所使用的工具和方法，努力阐明它们为何如此奏效。

第四，本书有很大一部分讨论深度多层感知机。我们作出这一选择，是为了以教学上清晰的方式展示有效理论框架的力量，而不是因为存在任何技术障碍；同时，我们也会指出如何把这一形式体系推广到其他值得关注的架构。事实上，我们预计许多结果具有广泛的适用性，并尽力聚焦于那些有望为深度学习共同体带来持久且普适价值的方面。

第五，尽管本书的许多材料都是新颖的，并且首次在这里出现；尽管我们的框架、记号、语言和侧重点在许多方面都与历史发展脉络不同，但我们同样深受深度学习共同体的惠泽。有鉴于此，我们将在全书中尽力引用重要的先前贡献，重点放在近年的基础性深度学习成果上，而不追求面面俱到。感兴趣的读者很容易从我们引用的工作中找到更多参考资料。

第六，本书最初源于一个同 Boris Hanin 合作的研究项目。为了铭记他的付出以及之后给予的支持，我们特意在封面上纪念他。更广泛地说，我们以不同方式受益于 Rafael Araujo、Léon Bottou、Paul Dirac、Ethan Dyer、John Frank、Ross Girshick、Vince Higgs、Yoni Kahn、Yann LeCun、Kyle Mahowald、Eric Mintun、Xiaoliang Qi、Mike Rabbat、David Schwab、Stephen Shenker、Eva Silverstein、PJ Steiner、DJ Strouse 和 Jesse Thaler 提供的艺术创作、讨论、鼓励、题词、反馈、管理、审稿、重新引介与支持。在组织层面，我们感谢 FAIR 与 Facebook、Diffee 与 Salesforce、MIT 与 IAIFI，以及 Cambridge University Press 与 arXiv。

第七，鉴于撰写本书所需投入的巨大（且在许多方面难以确定的）时空和能量-动量，Dan 感谢 Aya、Lumi 与 Lisa Yaida；从对偶的样本空间视角看，Sho 感谢 Adrienne Rothschilds，并且也会追溯性地感谢任何假想的、未来名为 Mark 或 Emily 的人——若他们存在，本来就会在本段受到致谢。

第八，我们希望本书能够传播我们的乐观信念：一种深度学习的一般理论确实是可能的；它既能从第一性原理导出，同时又专注于描述现实模型实际上怎样工作——实践中近乎简单的现象，应当对应于近乎简单的有效理论。我们梦想，这种思考方式不仅会带来更/已删节/的 AI 模型，也会引导我们走向一个统一框架，以理解智能的普适方面。

仿佛用这套八重道为本书作序还不够接近过量似的，请注意：本书有一个网站，deeplearningtheory.com。你也许会想访问它，以确认自己刚刚发现的错误是否已经是众所周知的。如果还不是，请告诉我们。也许会有馅饼。

Dan Roberts & Sho Yaida
远程所在地
2021 年 6 月

目录

1 序言	i
0 初始化	1
0.1 有效理论方法	2
0.2 理论最低限度	3
稀疏性原理	6
1 预训练	9
1.1 高斯积分	10

单变量高斯积分	10
多元高斯积分	13
1.2 概率、相关与统计，以及诸如此类的一切	17
1.3 近高斯分布	21
二次作用量与高斯分布	22
四次作用量与微扰理论	22
旁论：统计独立性与相互作用	25
近高斯作用量	26
2 神经网络	29
2.1 函数逼近	29
2.2 激活函数	34
感知机	34
Sigmoid	34
Tanh	34
Sin	36
尺度不变：线性、ReLU 与 leaky ReLU	36
类 ReLU: softplus、SWISH 与 GELU	37
2.3 系综	37
偏置与权重的初始化分布	38
诱导分布	39
确定性分布与 Dirac delta 函数	39
再论诱导分布	41
3 初始化时深度线性网络的有效理论	42
3.1 深度线性网络	43
3.2 临界性	44
数学：二点相关子的递推	44
物理：临界性	45
3.3 涨落	46
数学：四点相关子的递推	47
物理：大 n 展开、非高斯性、相互作用与涨落	49
3.4 混沌	51
数学：六点及高阶相关子的递推	51
物理：微扰论失效与混沌涌现	54

4 预激活量的表征群流	56
4.1 第一层：经典高斯	57
Wick 路径：通过相关子的组合推导	58
Hubbard–Stratonovich 路径：通过作用量的代数推导	60
高斯作用量的应用	61
4.2 第二层：非高斯性的诞生	62
第二层条件分布	63
Wick Wick Wick：组合推导	64
Schwinger–Dyson 法：代数推导	67
近高斯作用量的应用	69
4.3 更深层：非高斯性的累积	71
递归	71
作用量	73
大宽度展开	74
4.4 边缘化规则	76
对样本边缘化	76
对神经元边缘化	77
部分边缘化下的跑动耦合	78
4.5 次领先修正	80
4.6 RG 流与 RG 流	82
5 初始化时预激活量的有效理论	87
5.1 核的临界性分析	88
单个输入	89
两个输入	90
推导自举递归	93
小结	96
5.2 尺度不变激活函数的临界性	98
5.3 超越尺度不变激活函数的普适性	99
5.3.1 一般策略	100
5.3.2 不存在临界性：sigmoid、softplus、非线性单项式等	101
5.3.3 $K^* = 0$ 普适类：tanh、sin 等	103
中点核的深度渐近分析	104
平行扰动的深度渐近分析	106

垂直扰动的深度渐近分析	106
5.3.4 半稳定普适类: SWISH 等与 GELU 等	107
5.4 涨落	109
单输入, 再探	110
5.4.1 尺度不变普适类的涨落	110
5.4.2 $K^* = 0$ 普适类的涨落	112
四点顶点	112
裸 NLO 度量	113
重整化 NLO 度量	114
5.5 尺度不变普适类的有限夹角分析	116
极角的 RG 流	116
极角的临界性分析	119
6 贝叶斯学习	122
6.1 贝叶斯概率	123
6.2 贝叶斯推断与神经网络	125
6.2.1 贝叶斯模型拟合	125
模型边缘化的近似方法: MAP 与 MLE	128
模型边缘化的精确方法: 有效理论	129
6.2.2 贝叶斯模型比较	131
奥卡姆剃刀	132
归纳偏置	132
6.3 无限宽下的贝叶斯推断	133
6.3.1 临界性的证据	134
6.3.2 不要连接在一起	137
6.3.3 表征学习的缺失	140
6.4 有限宽下的贝叶斯推断	141
6.4.1 Hebb 学习有限公司	141
6.4.2 连接在一起	144
6.4.3 表征学习的存在	146
7 基于梯度的学习	150
7.1 监督学习	151
7.2 梯度下降与函数逼近	152
张量梯度下降	153

神经正切核	154
8 神经正切核的表征群流	156
8.0 NTK 的前向方程	157
有效理论中的缩放	159
把事情弄反了	160
8.1 第一层：确定性 NTK	161
8.2 第二层：涨落的 NTK	162
8.3 更深层：NTK 涨落的累积	165
8.3.0 层间插曲：层间相关	165
8.3.1 NTK 均值	169
8.3.2 NTK-预激活交叉相关	170
D -递推	172
F -递推	173
8.3.3 NTK 方差	174
B -递推	175
A -递推	176
9 初始化时 NTK 的有效理论	179
9.1 NTK 的临界性分析	179
单输入的领先阶 NTK 递推	180
缩放律的相关性	183
形式性：垂直扰动与冻结 NTK	184
9.2 尺度不变普适类	184
NTK 均值（冻结 NTK）	185
NTK 方差与 NTK-预激活交叉相关（受扰 NTK）	186
9.3 $K^* = 0$ 普适类	187
NTK 均值（冻结 NTK）	188
NTK 方差与 NTK-预激活交叉相关（受扰 NTK）	189
9.4 临界性、爆炸与消失问题，以及这些问题的消失	191
关于梯度爆炸与消失问题的传统观点	191
关于梯度爆炸与消失问题的临界观点	192
学习率的等效原理	193
10 核学习	195

10.1 一小步	196
10.1.1 无连线	197
10.1.2 无表征学习	198
10.2 巨大飞跃	199
10.2.1 Newton 方法	199
10.2.2 算法无关性	203
10.2.3 插叙：交叉熵损失	205
10.2.4 核预测	206
梯度下降等于精确贝叶斯推断的唯一情形	208
10.3 泛化	209
10.3.1 偏差-方差权衡与临界性	211
$K^* = 0$ 普适类	213
尺度不变普适类	216
10.3.2 内插与外推	218
深线性网络的线性 $*$ -插推	218
光滑非线性深度网络的非线性 $*$ -插推	219
10.4 线性模型与核方法	222
10.4.1 线性模型	222
10.4.2 核方法	224
10.4.3 作为线性模型的无限宽度网络	226
11 表征学习	229
11.1 神经正切核的微分	230
11.2 dNTK 的 RG 流	233
11.2.0 dNTK 的前向方程	233
11.2.1 第一层：零 dNTK	236
11.2.2 第二层：非零 dNTK	236
11.2.3 更深层：增长的 dNTK	238
层间插曲 2：再论层间相关	238
dNTK-预激活量交叉相关	239
P -递推	242
Q -递推	243
11.3 初始化时 dNTK 的有效理论	245
11.3.1 尺度不变普适类	247
11.3.2 $K^* = 0$ 普适类	248
11.4 非线性模型与近核方法	251

11.4.1 非线性模型	251
近线性二次回归	253
旁论：线性回归与二次回归的模型比较	255
11.4.2 近核方法	256
已训练核预测	259
11.4.3 作为非线性模型的有限宽度网络	260
深度学习：表征学习的非最小模型	263
∞ 训练的终点	264
$\infty.1$ 另外两个微分	265
ddNTK 统计量	267
ddNTK 标度	269
$K^* = 0$ 普适类	270
尺度不变普适类	271
$\infty.2$ 有限宽度下的训练	273
有限宽度下的无限宽巨大飞跃	275
$\infty.2.1$ 巨大飞跃之后的一小步	277
第一次更新：梯度下降的最后一次推广	277
第二次更新：表征学习反击	280
$\infty.2.2$ 梯度下降的许许多多步	282
自由理论：与步数无关的 NTK	283
相互作用理论：动力学 NTK 与 dNTK	285
$\infty.2.3$ 有限宽下的预测	296
有限宽下的泛化	301
训练算法的归纳偏置	303
梯度下降无处等于精确贝叶斯推断	304
$\infty.3$ ddNTK 的 RG 流：完整表达式	305
$\widehat{\text{dd}_I H}$ 随机前向方程	305
$\widehat{\text{dd}_\Pi H}$ 随机前向方程	306
$\widehat{\text{dd}_I H}$ 递推	306
$\widehat{\text{dd}_\Pi H}$ 递推	307
ε 宏观视角下的模型复杂度	309
无限宽下的稀疏性	310
有限宽下的近稀疏性	311
充分训练神经网络的模型复杂度	312
A 深度学习中的信息	316
A.1 熵与互信息	317

A.2 无限宽下的信息：临界性	323
A.3 有限宽下的信息：最优深宽比	325
领先阶修正：非零互信息	328
NLO 修正：最优深宽比与三元信息	330
B 残差学习	335
B.1 残差多层感知机	338
B.2 残差无限宽：临界性分析	338
B.3 残差有限宽：最优深宽比	340
尺度不变普适类	342
$K^* = 0$ 普适类	342
最优深宽比的物理学	343
B.4 残差构件	344
索引 356	
术语索引	376
术语索引 376	

第 0 章

初始化

这种模拟使得人们通常会同时感知数十亿个基本过程之和，以至于大数所导致的均化规律完全掩盖了各个过程的真实本质。

John von Neumann [2]

得益于对计算机技术的大量投入，现代**人工智能**（AI）系统如今可以配备数十亿个基本组件。当这些组件得到恰当的初始化并随后经过训练时，人工智能便能完成一些曾被认为复杂到不可思议的任务，以至于哲学家过去曾论证，只有自然智能系统——即人类——才能完成这些任务。

人工智能取得的诸多成功背后是**深度学习**。深度学习以人工**神经网络**作为人工智能的基础模型：虽然人工神经网络大致借鉴了生物神经网络，例如你的大脑，但最好还是把人工神经网络理解为一种格外便利的方式，用来规定一组灵活的函数；这些函数由许多称为**神经元**的基本计算模块构成。这种计算模型实际上与为你很可能正在用来阅读本书的计算机提供动力的模型颇为不同。具体而言，深度学习模型并不通过编程来直接指定一套解决问题的指令，而是在现实世界的的数据上接受训练，并学习如何解决问题。

深度学习框架真正的力量来自深度神经网络：许多神经元并行排列，并组织成依次相连的计算层，从而学习关于世界的有用表征。这种**表征学习**把数据转换成逐渐精炼的形式，以帮助解决底层任务；无论对人工智能还是生物智能而言，它都被认为是智能取得成功的标志性特征。

尽管深度学习取得了这些成功并引发了强烈关注，其理论仍处于襁褓之中。事实上，理论与实践之间存在严重脱节：实践者已经达成了令人惊叹的里程碑，并远远甩开了理论研究者；后者的分析往往包含极不现实的假设，因而所得结论与理解通常实际使用的深度神经网络无关。更重要的是，尽管大量经验证据表明“深度”对于该框架的成功至关重要，却很少有理论工作直面深度学习中的深度。

本书的目标是提出一组**原理**，使我们能够从理论上分析真正切合实际的深度神经网络。为了让你为这项任务做好初始化，本章余下部分将从非常高的层次解释：(i) 为什么这一目标在理论上确实可以实现；以及 (ii) 在实践中我们如何能够达成这一目标。

0.1 有效理论方法

蒸汽航行使相距最远的国家彼此接近。
...人们对其理论所知甚少，改进它们的尝试仍然几乎全凭偶然。...现在，我们打算对这些问题进行审慎考察。

Sadi Carnot, 论深度学习理论的必要性 [3].

现代深度学习模型虽然由看似数不胜数的基本计算组件构成，但从第一性原理出发，关于一个训练后的神经网络如何由这些底层组件计算函数的微观描述却完全是显式的。这种微观描述就是一组指令，用于让输入穿过由组件构成的许多层并转化为输出。重要的是，在训练过程中，这些组件会得到极为精细的调节；系统要产生有用的输出，就必须知道这些具体的调节结果。

遗憾的是，这些调节结果的复杂性遮蔽了任何从第一性原理出发的宏观理解，即深度神经网络为什么计算某个特定函数而不是另一个函数。许多神经元在这种计算中各自执行不同任务，因此，认为我们能够用理论理解这些模型似乎毫无希望；相信少数几条数学原理足以完成这项工作，似乎也很可笑。

幸运的是，**理论物理学**有着悠久传统，善于为由大量组件组成的复杂系统寻找简单的**有效理论**。物理学研究纲领在刻画我们的物理宇宙方面取得了巨大成功，这表明其中一些工具或许也能用于从理论上理解深度神经网络。为说明这种联系的动机，让我们极其简要地回顾一下热力学和统计力学的成功；这两种物理理论共同从微观第一性原理出发，解释了由许多基本组分构成的系统的宏观行为。

作为工业时代的一项科学产物，**热力学**源于描述并改进蒸汽机的努力——蒸汽机是一个包含极多粒子的系统，或许也是最早的黑箱。从细致经验观察中归纳出的热力学定律被用来系统表述蒸汽的力学，为这些正在改变社会的宏观人造机器提供高层次理解。热力学的出现虽然极大提高了蒸汽动力的效率，但它的定律绝非基本定律。

直到很久以后，Maxwell、Boltzmann 和 Gibbs 才补上了经验导出的有效描述与第一性原理理论之间缺失的环节。他们的**统计力学**解释了：描述人类尺度机器的宏观热力学定律，如何能够从许多微观基本组分的确定性动力学中以统计方式涌现出来。从这一视角看，热力学定律是涌现现象，只有通过数量极其庞大的微观粒子的集体统计行为才会出现。事实上，正是统计力学给出的细致理论预言，最终使得物质确实由分子和原子组成这一观点得到科学界的普遍接受。对统计力学坚持不懈的应用促成了量子力学的发现；量子力学又为晶体管的发明奠定了基础，后者推动了信息时代；而从长远来看，这一切使我们能够开始实现可以智能地思考的人造机器。

值得注意的是，这些物理理论源自理解蒸汽机之类人造工程对象的愿望。与一种可能存在的误解相反，物理学并不区分自然现象与人造现象。从最根本的层面说，物理学致力于提供一套统一原理，用以解释过去的经验观察并预言未来实验的结果；理论计算的要旨，是把可测量的结果或**可观测量**直接联系到定义该理论的底层基本常数或**参数**。这一视角还意味着，模型的预测准确性与其数学可处理性之间存在权衡；要使任何理论

取得成功，前者必须优先于后者：理论与物理现实之间必须有一条短而牢固的系绳。成功的理论能够提供对现象的全面理解，并推动技术上的实际进步；统计物理学架起的从蒸汽时代通往信息时代的桥梁便是明证。

对于我们研究深度学习而言，上述讨论的关键结论是：一个理论问题在由许多基本组分构成时反而会变得简单。此外，与一箱蒸汽中所含的水分子不同——水分子的存在一度还是有待实验验证的争议性猜想——构成深度神经网络的神经元是人为放入（这个箱子）的。确切地说，在这种情形下，我们已经理解微观定律——网络如何计算——因此我们的任务转而是理解宏观尺度上出现的新型规律性——它为什么计算某个特定函数而不是另一个函数——这些规律性从巨型深度学习模型的统计性质中涌现出来。

0.2 理论最低限度

方法比发现更重要，因为正确的方法将会带来新的、甚至更有价值的发现。

Lev Landau [4].

本节将从高层次概述我们的方法，并给出最低限度的解释，说明为什么我们应该预期，对深度神经网络进行第一性原理的理论理解是可能的。接下来的各章将补齐所有细节。

从本质上说，**神经网络**是一份计算函数的方案，由许多称为**神经元**的计算单元构成。每个神经元本身都是非常简单的函数：它考察输入信号的加权和，再把该和的值与某个阈值比较，从而以特定方式激发。随后，神经元并行组织成**层**，而深度神经网络则由多个依次相连的层组成。网络由激发阈值以及神经元之间的加权连接参数化；为了让读者感受其潜在规模，当前最先进的神经网络可以拥有超过一千亿个参数。图 0.1 展示了一个规模合理得多的神经网络的结构图。

暂且忽略所有这些结构，只把神经网络看作一个参数化函数

$$f(x; \theta), \quad (0.1)$$

其中 x 是函数的输入， θ 是由大量**参数**组成的向量，用于控制函数的形状。要让这样的函数有用，我们就需要以某种方式调节高维参数向量 θ 。实践中，这分两步完成：

- 首先，我们从一种计算上简单的概率分布中随机采样参数向量 θ ，以此初始化网络，

$$p(\theta). \quad (0.2)$$

稍后我们会讨论采用**初始化分布** $p(\theta)$ 为何在理论上是一种良策；但更重要的是，这正与实践中的做法相符，而本书所采用的方法正是让理论分析对应于现实的深度学习情形。




图 0.1: 一个简单多层神经网络的图, 展示了输入 x 如何依次经过中间信号 $s^{(1)}$ 、 $s^{(2)}$ 和 $s^{(3)}$ 的变换, 最终成为输出 $f(x; \theta)$. 白色圆圈表示神经元, 顶部的黑点表示网络输出, 而参数 θ 隐含在图中; 这些参数为传递信号的不同箭头的重要性赋予权重, 并使每个神经元的激发阈值产生偏置.

- 其次, 我们按照 $\theta \rightarrow \theta^*$ 调整参数向量, 使得到的网络函数 $f(x; \theta^*)$ 尽可能接近期望的目标函数 $f(x)$:

$$f(x; \theta^*) \approx f(x). \quad (0.3)$$

这称为**函数逼近**. 为了找到这些调节值 θ^* , 我们把网络函数 $f(x; \theta)$ 拟合到**训练数据**; 训练数据由许多形如 $(x, f(x))$ 的数据对组成, 它们是从期望的、但只能部分观测的目标函数 $f(x)$ 中观测到的. 总体而言, 对参数作出这些调整称为**训练**, 而用于调节参数的具体程序称为**学习算法**.

我们的目标是理解这个训练后的网络函数:

$$f(x; \theta^*). \quad (0.4)$$

具体而言, 我们希望从用训练后参数 θ^* 表述的网络第一性原理微观描述出发, 理解该函数的宏观行为. 我们还希望理解函数逼近 (0.3) 如何运作, 并评估 $f(x; \theta^*)$ 在逼近 $f(x)$ 时如何使用训练数据 $(x, f(x))$. 鉴于参数 θ 的高维性, 以及逼近 (0.3) 所需的精细调节程度, 这一目标或许显得天真, 超出了任何现实理论方法所能企及的范围.

要更直接地看出我们将会遇到哪些技术问题, 一种办法是在参数的初始化值 θ 附近对训练后的网络函数 $f(x; \theta^*)$ 作 *Taylor* 展开. 暂且只作示意, 并忽略 θ 是向量以及 $f(x; \theta)$ 的导数是张量这一事实, 我们得到

$$f(x; \theta^*) = f(x; \theta) + (\theta^* - \theta) \frac{df}{d\theta} + \frac{1}{2} (\theta^* - \theta)^2 \frac{d^2 f}{d\theta^2} + \dots, \quad (0.5)$$

其中, 右边的 $f(x; \theta)$ 及其各阶导数均在参数的初始化值处取值. 这个 *Taylor* 表示揭示了我们的三个主要问题:

问题 1

一般来说, 级数 (0.5) 包含无穷多项

$$f, \quad \frac{df}{d\theta}, \quad \frac{d^2f}{d\theta^2}, \quad \frac{d^3f}{d\theta^3}, \quad \frac{d^4f}{d\theta^4}, \quad \dots, \quad (0.6)$$

原则上, 要使用函数的 Taylor 表示 (0.5), 我们就需要计算所有这些项. 更具体地说, 训练后参数与初始化参数之差 $(\theta^* - \theta)$ 越大, 为了得到训练后网络函数 $f(x; \theta^*)$ 的良好近似, 所需的项数也越多.

问题 2

由于参数 θ 是从初始化分布 $p(\theta)$ 中随机采样的, 每次初始化网络时都会得到不同的函数 $f(x; \theta)$. 这意味着, (0.6) 中的每一项 f 、 $df/d\theta$ 、 $d^2f/d\theta^2$ 、... 实际上都是输入 x 的随机函数. 因此, 初始化会在网络函数及其导数上诱导出一个分布, 而我们需要确定映射

$$p(\theta) \rightarrow p\left(f, \frac{df}{d\theta}, \frac{d^2f}{d\theta^2}, \dots\right), \quad (0.7)$$

它把初始参数 θ 的分布映射为网络函数 $f(x; \theta)$ 、其**梯度** $df/d\theta$ 、其**Hessian 矩阵** $d^2f/d\theta^2$ 等量的联合分布. 这个联合分布由无穷多个随机函数组成, 而一般来说, 这些函数之间会有错综复杂的统计依赖关系. 即使暂且搁置这无穷多个函数, 只考察网络函数本身的边缘分布 $p(f)$, 也没有理由预期它在解析上是可处理的.

问题 3

参数的学习所得值 θ^* 是复杂训练过程的结果. 一般而言, θ^* 并不唯一, 而且可以依赖于一切:

$$\theta^* \equiv [\theta^*] \left(\theta, f, \frac{df}{d\theta}, \frac{d^2f}{d\theta^2}, \dots; \text{学习算法; 训练数据} \right). \quad (0.8)$$

实践中, 学习算法是迭代式的, 它在许多步骤中不断累积变化, 而且其动力学是非线性的. 因此, 训练后参数 θ^* 将以非常复杂的方式依赖于初始化时的所有量——例如参数 θ 的具体随机样本、网络函数 $f(x; \theta)$ 及其所有导数 $df/d\theta$ 、 $d^2f/d\theta^2$ 、...——也依赖于学习算法的细节, 以及构成训练数据的特定数据对 $(x, f(x))$. 要确定 θ^* 的解析表达式, 就必须把这一切都纳入考虑.

如果能够解决这三个问题, 那么原则上我们便可以使用 Taylor 级数表示 (0.5) 来研究训练后的网络函数. 更具体地说, 我们将得到训练后网络函数上的一个分布

$$p(f^*) \equiv p\left(f(x; \theta^*) \middle| \text{学习算法; 训练数据}\right), \quad (0.9)$$

此时它以一种简单方式以学习算法和我们用来训练的数据为条件. 这里所谓简单, 是指对于不同算法或不同训练数据选择, 我们都能容易地计算这个分布, 而不必每次都重新求解一个版本的**问题 3**. 建立一种解析计算 (0.9) 的方法, 是本书的一项主要目标.

当然, 对于一般的参数化函数 $f(x; \theta)$, 解决这三个问题是不可行的. 然而, 我们并非试图在一般情形下解决这些问题; 我们只关心由深度神经网络给出的函数. 因而, 上述问题的任何解法都必然需要利用神经网络函数的特定结构. 其中的具体机制构成了本书的基础; 在本节余下部分, 我们将尝试直观说明如何化解这些复杂性.

稀疏性原理

为了进一步说明神经网络的结构，请向前翻一点，再看一下图 0.1. 注意，在该图所示的网络中，每个中间层或隐藏层由五个神经元组成，而输入 x 会穿过三个这样的隐藏层，最后一层之后才在顶部产生输出. 一般而言，神经网络架构的两个基本方面是其**宽度** n 和**深度** L .

正如我们在 §0.1 中预先提到的，在组件数量很大的极限下常常能够找到简化. 然而，仅仅考虑任意一个巨大的宏观系统并不足够，而选取正确的极限往往需要谨慎. 如果把神经元视为网络的组件，那么让网络规模增长基本上有两种主要方式：可以在保持深度 L 不变的同时增大宽度 n ，也可以在保持宽度 n 不变的同时增大深度 L . 在当前情形中，事实将会表明，前一种极限会使一切变得非常简单，而后一种极限则复杂得令人绝望，在实践中也毫无用处.

因此，让我们先从形式上取极限

$$\lim_{n \rightarrow \infty} p(f^*), \quad (0.10)$$

并研究该极限下的理想化神经网络. 这称为网络的**无限宽极限**；作为严格极限，它对于网络而言相当非物理：显然，你无法在有限计算机上直接编程实现一个具有无穷多个组件的函数. 然而，这一极端极限确实会大幅简化训练后网络上的分布 $p(f^*)$ ，使我们的三个问题全都变得无比温和：

- 对于**问题 1**，所有 $k \geq 2$ 的高阶导数项 $d^k f / d\theta^k$ 都会有效地消失，这意味着我们只需追踪两项，

$$f, \quad \frac{df}{d\theta}. \quad (0.11)$$

- 对于**问题 2**，这些随机函数的分布将相互独立，

$$\lim_{n \rightarrow \infty} p\left(f, \frac{df}{d\theta}, \frac{d^2 f}{d\theta^2}, \dots\right) = p(f) p\left(\frac{df}{d\theta}\right), \quad (0.12)$$

而且每个边缘分布因子都具有非常简单的形式.

- 对于**问题 3**，训练动力学变为线性的，并且完全不依赖于学习算法的细节，使我们能够得到 θ^* 的完整解析解，其闭合形式为

$$\lim_{n \rightarrow \infty} \theta^* = [\theta^*] \left(\theta, f, \frac{df}{d\theta}; \text{训练数据} \right). \quad (0.13)$$

因此，训练后分布 (0.10) 是一个均值非零的简单**高斯分布**，我们可以轻易分析这类网络正在计算的函数.

这些简化是**稀疏性原理**的结果. 尽管把网络扩展到拥有无穷多个组件，看起来似乎让它变得更复杂了，但从任意一个特定神经元的视角看，无穷多个信号的输入会使大多数导致的均化规律完全掩盖信号中的许多细节. 结果是，许多这类无限宽网络的有效理论在其描述中呈现出极端的稀疏性，例如允许进行截断 (0.11).

遗憾的是，形式上的无限宽极限 $n \rightarrow \infty$ 并不能很好地刻画深度神经网络：无限宽不仅是网络的一种非物理性质，由此得到的训练后分布 (0.10) 对于层数超过一层的网络还会造成理论描述与实际观察不符。具体来说，经验上已知，这类训练后网络上的分布确实依赖于训练所用学习算法的性质。此外，我们将详细表明，这样的无限宽网络无法学习其输入的特征：对于任意输入 x ，它在隐藏层中的变换 $s^{(1)}$ 、 $s^{(2)}$ 、... 都会保持为初始化时的状态，从而产生随机表征，并由此严重限制这类网络能够学习的函数类别。非平凡的**表征学习**已经由经验研究证明是多层网络的一项基本性质，因此，这确实突显了理论与现实之间的对应关系在严格无限宽极限下发生崩溃。

从理论视角看，这一极限的问题在于：考虑无穷多个输入信号，会冲淡每个神经元处的精细细节。特别是，这种无限累积会彻底消除神经元之间的微妙相关性，而这些相关性本会在表征学习的训练过程中得到放大。为取得进展，我们需要找到一种办法，恢复并研究现实的有限宽网络中神经元之间存在的**相互作用**。

循此思路，或许可以修正无限宽极限，并使修正项在宽度 n 很大时变得很小。为此，我们可以像在物理学中分析相互作用系统那样使用**微扰理论**，并用 $1/n$ 展开研究深度学习，把层宽度的倒数 $\epsilon \equiv 1/n$ 作为展开的小参数： $\epsilon \ll 1$ 。换言之，我们将从严格无限宽极限稍作退让，并通过下列展开计算训练后分布 (0.9)：

$$p(f^*) \equiv p^{\{0\}}(f^*) + \frac{p^{\{1\}}(f^*)}{n} + \frac{p^{\{2\}}(f^*)}{n^2} + \dots, \quad (0.14)$$

其中， $p^{\{0\}}(f^*) \equiv \lim_{n \rightarrow \infty} p(f^*)$ 是我们上面讨论的无限宽极限 (0.10)，而 $k \geq 1$ 时的 $p^{\{k\}}(f^*)$ 给出对这一极限的一系列修正。

本书尤其会计算第一个这样的修正，把展开截断为

$$p(f^*) \equiv p^{\{0\}}(f^*) + \frac{p^{\{1\}}(f^*)}{n} + O\left(\frac{1}{n^2}\right). \quad (0.15)$$

这一相互作用理论仍足够简单，足以让我们的三个问题变得可处理：

- 对于**问题 1**，现在所有 $k \geq 4$ 的高阶导数项 $d^k f / d\theta^k$ 都会有效地产生 $1/n^2$ 阶或更小的贡献，这意味着，为了捕捉 $1/n$ 阶的领头贡献，我们只需追踪四项：

$$f, \quad \frac{df}{d\theta}, \quad \frac{d^2 f}{d\theta^2}, \quad \frac{d^3 f}{d\theta^3}. \quad (0.16)$$

因此可以看出，稀疏性原理仍会约束对偶有效理论的描述，不过约束程度不如在无限宽极限中那么强。

- 对于**问题 2**，初始化时这些随机函数的分布

$$p\left(f, \frac{df}{d\theta}, \frac{d^2 f}{d\theta^2}, \frac{d^3 f}{d\theta^3}\right), \quad (0.17)$$

在 $1/n$ 阶将会近乎简单，而且我们能够用微扰理论完整地求出它。

- 对于**问题 3**，我们能够使用动力学微扰理论来驯服非线性训练动力学，并为 θ^* 找到一个闭合形式的解析解：

$$\theta^* = [\theta^*] \left(\theta, f, \frac{df}{d\theta}, \frac{d^2 f}{d\theta^2}, \frac{d^3 f}{d\theta^3}; \text{学习算法; 训练数据} \right). \quad (0.18)$$

特别地，这将使解对学习算法细节的依赖变得透明而明确。

因此，我们在 $1/n$ 阶对训练后分布的描述 (0.15) 将是一个**近高斯分布**。

除了在解析上可处理之外，这个截断到 $1/n$ 阶的描述还将实现我们的目标，即计算并理解训练后网络函数上的分布 $p(f^*)$ 。由于纳入了神经元之间的相互作用，这个描述依赖于学习算法的细节，而且正如我们将看到的，它包含非平凡的表征学习。因而，定性地讲，这个 $1/n$ 阶有效理论比无限宽描述更贴近现实神经网络，从而更适合作为理解深度学习的理论**最小模型**。

那么定量对应又如何呢？通过计算展开 (0.14) 的更高阶项，我们可以得到一系列愈加精细的描述；这些项是否也需要包括在内？

本书引入的形式体系使得计算 $1/n$ 展开中的这些附加项完全系统化——尽管可能有些繁琐——但研究领头修正的一个重要副产品，恰恰是对这种截断误差获得更深入的理解。具体来说，我们将发现，应当与宽度 n 比较的正确尺度是深度 L 。也就是说，我们将看到，展开 (0.14) 中各项的相对大小由深度与宽度之比给出：

$$r \equiv L/n. \quad (0.19)$$

这让我们可以用如下方式重新表述对无限宽与有限宽、浅层与深层的理解：

- 在严格极限 $r \rightarrow 0$ 下，神经元之间的相互作用关闭：无限宽极限 (0.10) 实际上是一个尚可的描述。然而，这些网络并非真正深度，因为它们的相对深度为零： $L/n = 0$ 。
- 在 $0 < r \ll 1$ 的区域，神经元之间存在非平凡的相互作用：截断到 $1/n$ 阶的有限宽有效理论 (0.15) 能够准确描述训练后的网络输出。这些网络是有效深度的。
- 在 $r \gg 1$ 的区域，神经元强耦合：网络将表现出混沌行为，而且不同实例之间存在巨大涨落，因此不存在有效描述。这些网络是过深的。

因此，大多数具有实际用途的网络事实上都有相当小的深宽比，所以我们截断到 $1/n$ 阶的描述 (0.15) 也会给出极好的定量对应。¹

由此可见，要真正描述多层神经网络的性质，即理解深度学习，就需要研究宽度很大但有限的网络。这样一来，我们将能够为现实的深度神经网络找到一种宏观的有效理论描述。

¹更准确地说，存在一个最优深宽比 r^* ，它把有效区域 $r \leq r^*$ 与无效区域 $r > r^*$ 分隔开来。在附录 A 中，我们将从信息论视角估计这个最优深宽比。在附录 B 中，我们还将说明如何引入残差连接，把最优深宽比 r^* 移向更大的值，使原先过深的网络在实践中也更容易训练，并且能够由我们的有效理论方法作出定量描述。

第 1 章

预训练

我对这门课最深刻的记忆，是它刚开始的时候：他并没有从某条深刻的自然原理或某个实验讲起，而是先复习了高斯积分。显然，接下来有些计算要做。

Joe Polchinski 回忆 Richard Feynman 的量子力学课程 [5].

本书的目标是发展出一套能够从理论上理解深度学习的原理。其中也许最重要的一条原理是，宽而深的神经网络由近高斯分布支配。因此，要读完本书，你需要熟练掌握高斯积分与微扰理论。本章的预训练将快速介绍这两套工具，并简要概览我们将用到的一些关键统计学概念。唯一的预备知识是熟练掌握线性代数、多元微积分和初等概率论。

基于这一考虑，我们首先在 §1.1 中详细讨论高斯积分。重点是计算高斯分布下单项式平均值的工具，最终导出 Wick 定理。

接着，在 §1.2 中，我们先一般性地讨论期望值与可观测量。把可观测量看作通过重复实验了解概率分布的途径，自然会引出矩与累积量等统计学概念，以及与之对应的物理学概念：完整 M 点相关函数和连通 M 点相关函数。我们尤其重视连通相关函数，因为它们直接刻画一个分布偏离高斯性的程度。

在 §1.3 中，我们引入概率分布的负对数概率表示，即作用量表示，并说明作用量如何让我们系统地变形高斯分布，从而紧凑地表示非高斯分布。特别地，我们聚焦近高斯分布；其中，对高斯性的偏离由作用量中的小耦合实现，并说明如何用微扰理论把非高斯耦合与连通相关函数等可观测量联系起来。通过对这些耦合作微扰处理，可以把近高斯分布的任意相关函数转化为一组高斯积分之和；每个积分再用 §1.1 中发展的工具求值。这将是本书最重要的技巧之一，因为我们研究的神经网络都由近高斯分布支配，而且随着网络变宽，其非高斯耦合在微扰意义下会变小。

由于我们必须对所有这些操作运用自如，本章宁可写得详尽一些——无论文字、公式还是例子——以使这些材料尽可能透明易懂。

1.1 高斯积分

本节旨在介绍高斯积分和高斯概率分布，并最终推导 Wick 定理 (1.45). 该定理给出了计算多元高斯分布任意矩的可操作公式，并将在全书中反复使用.

单变量高斯积分

我们放慢脚步，从最简单的单变量高斯函数开始，

$$e^{-\frac{z^2}{2}}. \quad (1.1)$$

该函数的图像就是著名的钟形曲线：它关于峰值 $z = 0$ 对称，并在 $|z| \gg 1$ 时迅速衰减. 仅凭 (1.1) 还不能构成概率分布，因为它尚未归一化. 为求出正确的归一化，我们需要计算高斯积分

$$I_1 \equiv \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2}}. \quad (1.2)$$

作为一个古老的对象，这个积分有一种漂亮的求值技巧. 首先考虑它的平方

$$I_1^2 = \left(\int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2}} \right)^2 = \int_{-\infty}^{\infty} dx e^{-\frac{x^2}{2}} \int_{-\infty}^{\infty} dy e^{-\frac{y^2}{2}} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} dxdy e^{-\frac{1}{2}(x^2+y^2)}, \quad (1.3)$$

其中在中间一步只是改变了哑积分变量的名称. 然后改用极坐标 $(x, y) = (r \cos \phi, r \sin \phi)$ ；积分测度变为 $dxdy = r dr d\phi$ ，于是只需计算两个初等积分：

$$\begin{aligned} I_1^2 &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} dxdy e^{-\frac{1}{2}(x^2+y^2)} = \int_0^{\infty} r dr \int_0^{2\pi} d\phi e^{-\frac{r^2}{2}} \\ &= 2\pi \int_0^{\infty} dr r e^{-\frac{r^2}{2}} = 2\pi \left| -e^{-\frac{r^2}{2}} \right|_{r=0}^{r=\infty} = 2\pi. \end{aligned} \quad (1.4)$$

最后取平方根，得到高斯积分 (1.2)

$$I_1 = \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2}} = \sqrt{2\pi}. \quad (1.5)$$

用高斯函数除以这个归一化因子，定义方差为一的**高斯概率分布**

$$p(z) \equiv \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}, \quad (1.6)$$

它现在已正确归一化，即 $\int_{-\infty}^{\infty} dz p(z) = 1$. 这种均值为零、方差为一的分布有时称为标准正态分布.

把这个结果推广到**方差**为 $K > 0$ 的高斯分布非常容易. 相应的归一化因子为

$$I_K \equiv \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} = \sqrt{K} \int_{-\infty}^{\infty} du e^{-\frac{u^2}{2}} = \sqrt{2\pi K}, \quad (1.7)$$

其中中间一步把积分变量重标度为 $u = z/\sqrt{K}$. 于是可将方差为 K 的高斯分布定义为

$$p(z) \equiv \frac{1}{\sqrt{2\pi K}} e^{-\frac{z^2}{2K}}. \quad (1.8)$$

该分布的图像仍是关于 $z = 0$ 对称的钟形曲线, 但现在具有刻画其宽度的尺度 K , 在 $|z| \gg \sqrt{K}$ 时衰减. 更一般地, 可将钟形曲线的中心平移为

$$p(z) \equiv \frac{1}{\sqrt{2\pi K}} e^{-\frac{(z-s)^2}{2K}}, \quad (1.9)$$

使其关于 $z = s$ 对称. 中心值 s 称为分布的**均值**, 因为

$$\begin{aligned} \mathbb{E}[z] &\equiv \int_{-\infty}^{\infty} dz p(z) z = \frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{(z-s)^2}{2K}} z \\ &= \frac{1}{I_K} \int_{-\infty}^{\infty} dw e^{-\frac{w^2}{2K}} (s + w) \\ &= \frac{s I_K}{I_K} + \frac{1}{I_K} \int_{-\infty}^{\infty} dw \left(e^{-\frac{w^2}{2K}} w \right) \\ &= s, \end{aligned} \quad (1.10)$$

其中中间将变量平移为 $w = z - s$; 最后一步注意到第二项的被积函数在积分变量变号 $w \leftrightarrow -w$ 下为奇函数, 因而积分为零.

下面聚焦均值为零的高斯分布, 考虑一般函数 $\mathcal{O}(z)$ 的其他**期望值**, 即

$$\mathbb{E}[\mathcal{O}(z)] \equiv \int_{-\infty}^{\infty} dz p(z) \mathcal{O}(z) = \frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} \mathcal{O}(z). \quad (1.11)$$

我们常把这种函数 $\mathcal{O}(z)$ 称为**可观测测量**, 因为它们可对应实验的测量结果. 一类特殊的期望值称为**矩**, 对应对任意整数 M 在被积函数中插入 z^M :

$$\mathbb{E}[z^M] = \frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} z^M. \quad (1.12)$$

注意, 当指数 M 为奇数时积分为零, 因为被积函数在 $z \leftrightarrow -z$ 下为奇函数. 对于偶数个 z 插入, 即 $M = 2m$, 需计算

$$I_{K,m} \equiv \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} z^{2m}. \quad (1.13)$$

它与 (1.2) 几乎同样古老, 也有一种漂亮的求值技巧:

$$\begin{aligned} I_{K,m} &= \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} z^{2m} = \left(2K^2 \frac{d}{dK} \right)^m \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} = \left(2K^2 \frac{d}{dK} \right)^m I_K \\ &= \left(2K^2 \frac{d}{dK} \right)^m \sqrt{2\pi} K^{\frac{1}{2}} = \sqrt{2\pi} K^{\frac{2m+1}{2}} (2m-1)(2m-3)\cdots 1, \end{aligned} \quad (1.14)$$

其中第二行代入了 I_K 的表达式 (1.7). 因此偶数阶矩满足简单公式²

$$\mathbb{E}[z^{2m}] = \frac{I_{K,m}}{\sqrt{2\pi K}} = K^m (2m-1)!!, \quad (1.15)$$

其中引入了双阶乘

$$(2m-1)!! \equiv (2m-1)(2m-3)\cdots 1 = \frac{(2m)!}{2^m m!}. \quad (1.16)$$

结果 (1.15) 就是单变量高斯分布的 Wick 定理.

实际上还有另一种很好的方法推导 (1.15), 而且它能更自然地推广到多元高斯分布. 这一推导从考虑带有**源项** J 的高斯积分开始, 定义

$$Z_{K,J} \equiv \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K} + Jz}. \quad (1.17)$$

令源为零便恢复高斯积分的归一化, 因而 $Z_{K,J=0} = I_K$. 在物理学文献中, $Z_{K,J}$ 有时称为**带源配分函数**; 很快会看到, 该积分是矩的**生成函数**. 对指数配方可求得 $Z_{K,J}$:

$$-\frac{z^2}{2K} + Jz = -\frac{(z - JK)^2}{2K} + \frac{KJ^2}{2}, \quad (1.18)$$

于是积分 (1.17) 可写成

$$Z_{K,J} = e^{\frac{KJ^2}{2}} \int_{-\infty}^{\infty} dz e^{-\frac{(z-JK)^2}{2K}} = e^{\frac{KJ^2}{2}} I_K = e^{\frac{KJ^2}{2}} \sqrt{2\pi K}, \quad (1.19)$$

其中中间等式利用了被积函数只是方差为 K 的平移高斯函数.

现在可把带源高斯积分 $Z_{K,J}$ 与带插入高斯积分 $I_{K,m}$ 联系起来. 先对源 J 求导, 然后令源为零, 得到

$$I_{K,m} = \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} z^{2m} = \left[\left(\frac{d}{dJ} \right)^{2m} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K} + Jz} \right] \Big|_{J=0} = \left[\left(\frac{d}{dJ} \right)^{2m} Z_{K,J} \right] \Big|_{J=0}. \quad (1.20)$$

换言之, 积分 $I_{K,m}$ 就对应配分函数 $Z_{K,J}$ 在 $J=0$ 附近的偶次 Taylor 系数. 例如, 当 $2m=2$ 时

$$\mathbb{E}[z^2] = \frac{I_{K,1}}{\sqrt{2\pi K}} = \left[\left(\frac{d}{dJ} \right)^2 e^{\frac{KJ^2}{2}} \right] \Big|_{J=0} = \left[e^{\frac{KJ^2}{2}} (K + K^2 J^2) \right] \Big|_{J=0} = K, \quad (1.21)$$

当 $2m=4$ 时

$$\mathbb{E}[z^4] = \frac{I_{K,2}}{\sqrt{2\pi K}} = \left[\left(\frac{d}{dJ} \right)^4 e^{\frac{KJ^2}{2}} \right] \Big|_{J=0} = \left[e^{\frac{KJ^2}{2}} (3K^2 + 6K^3 J^2 + K^4 J^4) \right] \Big|_{J=0} = 3K^2. \quad (1.22)$$

²令此式中的 $2m=2$, 便清楚说明了为何把 K 称作方差: 对于均值为零、方差为 K 的高斯分布, $\text{var}(z) \equiv \mathbb{E}[(z - \mathbb{E}[z])^2] = \mathbb{E}[z^2] - \mathbb{E}[z]^2 = \mathbb{E}[z^2] = K$.

注意, 令 $J = 0$ 后, 所有悬空源项都会消失. 由此得到计算一般 m 的相关函数的简单方法: 对指数 $Z_{K,J}/I_K = \exp\left(\frac{KJ^2}{2}\right)$ 作 Taylor 展开, 只保留源的数目恰好使表达式不消失的项. 这样便有

$$\begin{aligned}\mathbb{E}[z^{2m}] &= \frac{I_{K,m}}{\sqrt{2\pi K}} = \left[\left(\frac{d}{dJ} \right)^{2m} e^{\frac{KJ^2}{2}} \right] \Big|_{J=0} = \left\{ \left(\frac{d}{dJ} \right)^{2m} \left[\sum_{k=0}^{\infty} \frac{1}{k!} \left(\frac{K}{2} \right)^k J^{2k} \right] \right\} \Big|_{J=0} \\ &= \left(\frac{d}{dJ} \right)^{2m} \left[\frac{1}{m!} \left(\frac{K}{2} \right)^m J^{2m} \right] = K^m \frac{(2m)!}{2^m m!} = K^m (2m-1)!!,\end{aligned}\tag{1.23}$$

这就完成了单变量高斯分布的 Wick 定理 (1.15) 的第二种推导. 这个推导远长于第一种漂亮的推导, 却能非常自然地推广到多元高斯分布; 下面就转向这一情形.

多元高斯积分

现在加快速度, 处理 N 维变量 z_μ ($\mu = 1, \dots, N$) 的多元高斯积分.³ 多元高斯函数定义为

$$\exp \left[-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu \right], \tag{1.24}$$

其中方差或**协方差矩阵** $K_{\mu\nu}$ 是 $N \times N$ 对称正定矩阵, 其逆 $(K^{-1})_{\mu\nu}$ 定义为使二者矩阵乘积等于 $N \times N$ 单位矩阵:

$$\sum_{\rho=1}^N (K^{-1})_{\mu\rho} K_{\rho\nu} = \delta_{\mu\nu}. \tag{1.25}$$

这里还引入了 **Kronecker delta** $\delta_{\mu\nu}$, 满足

$$\delta_{\mu\nu} \equiv \begin{cases} 1, & \mu = \nu, \\ 0, & \mu \neq \nu. \end{cases} \tag{1.26}$$

Kronecker delta 只是单位矩阵的一种方便表示.

为从高斯函数 (1.24) 构造概率分布, 仍需计算归一化因子

$$\begin{aligned}I_K &\equiv \int d^N z \exp \left[-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu \right] \\ &= \int_{-\infty}^{\infty} dz_1 \int_{-\infty}^{\infty} dz_2 \cdots \int_{-\infty}^{\infty} dz_N \exp \left[-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu \right].\end{aligned}\tag{1.27}$$

为计算该积分, 先回忆线性代数中的事实: 给定 $N \times N$ 对称矩阵 $K_{\mu\nu}$, 总存在正交矩阵⁴ $O_{\mu\nu}$, 使 $K_{\mu\nu}$ 对角化为 $(OKO^T)_{\mu\nu} = \lambda_\mu \delta_{\mu\nu}$, 其特征值为 $\lambda_{\mu=1, \dots, N}$; 同时其逆对角化

³ 全书将尽可能显式写出向量、矩阵和张量的分量指标; 仅在少数由语境已经足够清楚的情况省略.

⁴ 正交矩阵 $O_{\mu\nu}$ 是转置 $(O^T)_{\mu\nu}$ 等于其逆的矩阵, 即 $(O^T O)_{\mu\nu} = \delta_{\mu\nu}$.

为 $(OK^{-1}O^T)_{\mu\nu} = (1/\lambda_\mu) \delta_{\mu\nu}$. 据此, 把单位矩阵 $\delta_{\mu\nu} = (O^T O)_{\mu\nu}$ 插入两次, 积分指数中的和可用特征值表示为

$$\begin{aligned} \sum_{\mu,\nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu &= \sum_{\mu,\rho,\sigma,\nu=1}^N z_\mu (O^T O)_{\mu\rho} (K^{-1})_{\rho\sigma} (O^T O)_{\sigma\nu} z_\nu \\ &= \sum_{\mu,\nu=1}^N (Oz)_\mu (OK^{-1}O^T)_{\mu\nu} (Oz)_\nu \\ &= \sum_{\mu=1}^N \frac{1}{\lambda_\mu} (Oz)_\mu^2, \end{aligned} \quad (1.28)$$

最后一行使用了逆协方差矩阵的对角化性质. 正定矩阵 $K_{\mu\nu}$ 的特征值均为正, 即 $\lambda_\mu > 0$; 由此可见, λ_μ 决定高斯函数沿各特征方向的衰减尺度. 再回忆多元微积分中的事实: 用正交矩阵 O 作变量替换 $u_\mu \equiv (Oz)_\mu$, 积分测度不变, 即 $d^N z = d^N u$. 因而多元高斯积分 (1.27) 可分解为单变量高斯积分 (1.7) 的乘积:

$$\begin{aligned} I_K &= \int_{-\infty}^{\infty} du_1 \int_{-\infty}^{\infty} du_2 \cdots \int_{-\infty}^{\infty} du_N \exp\left(-\frac{u_1^2}{2\lambda_1} - \frac{u_2^2}{2\lambda_2} - \cdots - \frac{u_N^2}{2\lambda_N}\right) \\ &= \prod_{\mu=1}^N \left[\int_{-\infty}^{\infty} du_\mu \exp\left(-\frac{u_\mu^2}{2\lambda_\mu}\right) \right] = \prod_{\mu=1}^N \sqrt{2\pi\lambda_\mu} = \sqrt{\prod_{\mu=1}^N (2\pi\lambda_\mu)}. \end{aligned} \quad (1.29)$$

最后再回忆一个线性代数事实: 矩阵特征值的乘积等于其行列式. 因此多元高斯积分可紧凑写为

$$I_K = \int d^N z \exp\left[-\frac{1}{2} \sum_{\mu,\nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu\right] = \sqrt{|2\pi K|}, \quad (1.30)$$

其中 $|A|$ 表示方阵 A 的行列式.

求出归一化因子后, 可定义方差为 $K_{\mu\nu}$ 的零均值**多元高斯概率分布**

$$p(z) = \frac{1}{\sqrt{|2\pi K|}} \exp\left[-\frac{1}{2} \sum_{\mu,\nu=1}^N z_\mu (K^{-1})_{\mu\nu} z_\nu\right]. \quad (1.31)$$

同时约定省略逆协方差 $(K^{-1})_{\mu\nu}$ 上标中的“-1”, 改把分量指标写在上方:

$$K^{\mu\nu} \equiv (K^{-1})_{\mu\nu}. \quad (1.32)$$

这样便以分量指标是下标还是上标来区分协方差 $K_{\mu\nu}$ 与逆协方差 $K^{\mu\nu}$. 采用这一源自广义相对论的记号, 逆协方差的定义式 (1.25) 改写为

$$\sum_{\rho=1}^N K^{\mu\rho} K_{\rho\nu} = \delta^\mu_\nu, \quad (1.33)$$

而多元高斯分布 (1.31) 写为

$$p(z) = \frac{1}{\sqrt{|2\pi K|}} \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu K^{\mu\nu} z_\nu\right). \quad (1.34)$$

这个记号也许需要适应, 但既节省版面, 也减轻手写负担.⁵ 无论怎样书写, 零均值多元高斯概率分布 (1.34) 都在 $z = 0$ 处取峰值, 其沿各方向的衰减由协方差矩阵 $K_{\mu\nu}$ 决定. 更一般地, 可把高斯分布的峰平移到 s_μ :

$$p(z) = \frac{1}{\sqrt{|2\pi K|}} \exp\left[-\frac{1}{2} \sum_{\mu, \nu=1}^N (z - s)_\mu K^{\mu\nu} (z - s)_\nu\right], \quad (1.35)$$

这定义了均值 $\mathbb{E}[z_\mu] = s_\mu$ 、协方差 $K_{\mu\nu}$ 的一般多元高斯分布. 这是高斯分布最一般的形式.

下面考虑零均值多元高斯分布的矩

$$\begin{aligned} \mathbb{E}[z_{\mu_1} \cdots z_{\mu_M}] &\equiv \int d^N z \, p(z) \, z_{\mu_1} \cdots z_{\mu_M} \\ &= \frac{1}{\sqrt{|2\pi K|}} \int d^N z \, \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu K^{\mu\nu} z_\nu\right) z_{\mu_1} \cdots z_{\mu_M} = \frac{I_{K,(\mu_1, \dots, \mu_M)}}{I_K}, \end{aligned} \quad (1.36)$$

其中引入带插入的多元高斯积分

$$I_{K,(\mu_1, \dots, \mu_M)} \equiv \int d^N z \, \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu K^{\mu\nu} z_\nu\right) z_{\mu_1} \cdots z_{\mu_M}. \quad (1.37)$$

沿用单变量情形的方法, 引入源项 J^μ , 为积分 $I_{K,(\mu_1, \dots, \mu_M)}$ 构造生成函数:

$$Z_{K,J} \equiv \int d^N z \, \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu K^{\mu\nu} z_\nu + \sum_{\mu=1}^N J^\mu z_\mu\right). \quad (1.38)$$

顾名思义, 对生成函数 $Z_{K,J}$ 关于源 J^μ 求导会带下一个 z_μ 因子; 求导 M 次后

$$\begin{aligned} &\left[\frac{d}{dJ^{\mu_1}} \frac{d}{dJ^{\mu_2}} \cdots \frac{d}{dJ^{\mu_M}} Z_{K,J} \right] \Big|_{J=0} \\ &= \int d^N z \, \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N z_\mu K^{\mu\nu} z_\nu\right) z_{\mu_1} \cdots z_{\mu_M} = I_{K,(\mu_1, \dots, \mu_M)}. \end{aligned} \quad (1.39)$$

因此, 与单变量情形一样, 配分函数 $Z_{K,J}$ 在 $J^\mu = 0$ 附近的 Taylor 系数直接给出带插入积分 $I_{K,(\mu_1, \dots, \mu_M)}$. 若知道 $Z_{K,J}$ 的闭式表达式, 就可容易地算出这些积分.

⁵如果愿意, 你还可于笔记里彻底采用广义相对论风格的 *Einstein* 求和约定: 凡指标以上下成对方式重复出现, 就省略求和号. 例如, 采用该约定后, 逆的定义式只写成 $K^{\mu\rho} K_{\rho\nu} = \delta^\mu_\nu$, 高斯函数写成 $\exp(-\frac{1}{2} z_\mu K^{\mu\nu} z_\nu)$.

具体到神经网络, 你可能会发现 *Einstein* 求和约定对样本指标很方便, 但对神经元指标有时反而令人困惑. 为了格外清楚, 本书正文不采用该约定; 这里仍加以说明, 因为我们私下计算时常用它来化简.

为得到生成函数 $Z_{K,J}$ 的闭式, 仍仿照单变量情形, 对 (1.38) 的被积函数指数配方:

$$\begin{aligned}
& -\frac{1}{2} \sum_{\mu,\nu=1}^N z_\mu K^{\mu\nu} z_\nu + \sum_{\mu=1}^N J^\mu z_\mu \\
& = -\frac{1}{2} \sum_{\mu,\nu=1}^N \left(z_\mu - \sum_{\rho=1}^N K_{\mu\rho} J^\rho \right) K^{\mu\nu} \left(z_\nu - \sum_{\lambda=1}^N K_{\nu\lambda} J^\lambda \right) + \frac{1}{2} \sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \\
& = -\frac{1}{2} \sum_{\mu,\nu=1}^N w_\mu K^{\mu\nu} w_\nu + \frac{1}{2} \sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu,
\end{aligned} \tag{1.40}$$

其中引入平移变量 $w_\mu \equiv z_\mu - \sum_{\rho=1}^N K_{\mu\rho} J^\rho$. 利用该替换可显式求得生成函数

$$\begin{aligned}
Z_{K,J} &= \exp \left(\frac{1}{2} \sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \right) \int d^N w \exp \left[-\frac{1}{2} \sum_{\mu,\nu=1}^N w_\mu K^{\mu\nu} w_\nu \right] \\
&= \sqrt{|2\pi K|} \exp \left(\frac{1}{2} \sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \right),
\end{aligned} \tag{1.41}$$

最后使用了多元积分 I_K 的公式 (1.30). 有了生成函数 $Z_{K,J}$ 的闭式 (1.41), 即可由 (1.39) 对其求导, 计算带插入高斯积分. 对偶数个插入 $M = 2m$, 得到优美的公式

$$\begin{aligned}
\mathbb{E}[z_{\mu_1} \cdots z_{\mu_{2m}}] &= \frac{I_{K,(\mu_1, \dots, \mu_{2m})}}{I_K} = \frac{1}{I_K} \left[\frac{d}{dJ^{\mu_1}} \cdots \frac{d}{dJ^{\mu_{2m}}} Z_{K,J} \right] \Bigg|_{J=0} \\
&= \frac{1}{2^m m!} \frac{d}{dJ^{\mu_1}} \frac{d}{dJ^{\mu_2}} \cdots \frac{d}{dJ^{\mu_{2m}}} \left(\sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \right)^m.
\end{aligned} \tag{1.42}$$

对奇数个插入 $M = 2m + 1$, 令 $J = 0$ 后会留下悬空的源, 故这些积分为零. 也可直接观察任意奇数阶矩的被积函数: 它在积分变量变号 $z_\mu \leftrightarrow -z_\mu$ 下为奇函数.

现在稍停片刻, 用这个公式计算几个矩. 当 $2m = 2$ 时

$$\mathbb{E}[z_{\mu_1} z_{\mu_2}] = \frac{1}{2} \frac{d}{dJ^{\mu_1}} \frac{d}{dJ^{\mu_2}} \left(\sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \right) = K_{\mu_1 \mu_2}. \tag{1.43}$$

这里用乘积求导法则对两个 J 求导共有 $2! = 2$ 种方式; 由于协方差对称, 即 $K_{\mu_1 \mu_2} = K_{\mu_2 \mu_1}$, 二者给出相同表达式. 式 (1.43) 证实了在多元情形把 $K_{\mu\nu}$ 称作协方差的理由: 它确实就是协方差.

当 $2m = 4$ 时, 得到更复杂的表达式

$$\begin{aligned}
\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] &= \frac{1}{2^2 2!} \frac{d}{dJ^{\mu_1}} \frac{d}{dJ^{\mu_2}} \frac{d}{dJ^{\mu_3}} \frac{d}{dJ^{\mu_4}} \left(\sum_{\mu,\nu=1}^N J^\mu K_{\mu\nu} J^\nu \right) \left(\sum_{\rho,\lambda=1}^N J^\rho K_{\rho\lambda} J^\lambda \right) \\
&= K_{\mu_1 \mu_2} K_{\mu_3 \mu_4} + K_{\mu_1 \mu_3} K_{\mu_2 \mu_4} + K_{\mu_1 \mu_4} K_{\mu_2 \mu_3}.
\end{aligned} \tag{1.44}$$

现在对四个 J 求导共有 $4! = 24$ 种方式, 而 μ 下方的四个辅助指标 1, 2, 3, 4 只有三种不同的配对方式. 每种配对因此有 $24/3 = 8 = 2^2 2!$ 个等价项, 恰好消去总系数 $1/(2^2 2!)$.

对一般的 $2m$ ，对源求导有 $(2m)!$ 种方式，其中每 $2^m m!$ 种彼此等价。因而共有 $(2m)!/(2^m m!) = (2m-1)!!$ 个不同项，对应 μ 下方 $2m$ 个辅助指标 $1, \dots, 2m$ 的 $(2m-1)!!$ 种不同配对。式 (1.42) 分母中的 $1/(2^m m!)$ 保证每项的系数归一为一。因此，多元高斯分布的矩一般可写为

$$\mathbb{E}[z_{\mu_1} \cdots z_{\mu_{2m}}] = \sum_{\text{所有配对}} K_{\mu_{k_1} \mu_{k_2}} \cdots K_{\mu_{k_{2m-1}} \mu_{k_{2m}}}, \quad (1.45)$$

再次强调，求和遍及 μ 下 $2m$ 个辅助指标的所有不同配对，结果包含上述 $(2m-1)!!$ 项。和式每一项中的每个协方差因子 $K_{\mu\nu}$ 称作一次 **Wick 收缩**，对应辅助指标的一种特定配对。每一项由 m 个不同的 Wick 收缩组成，代表配对全部辅助指标的一种不同方式。为确保理解配对规则，请回看 $2m=2$ 的情形 (1.43)——只有一次 Wick 收缩——以及 $2m=4$ 的情形 (1.44)——有三种进行两次 Wick 收缩的不同方式——并尝试算出 $2m=6$ 的情形；它给出 $(6-1)!! = 15$ 种进行三次 Wick 收缩的不同方式：

$$\begin{aligned} \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\mu_5} z_{\mu_6}] = & K_{\mu_1 \mu_2} K_{\mu_3 \mu_4} K_{\mu_5 \mu_6} + K_{\mu_1 \mu_3} K_{\mu_2 \mu_4} K_{\mu_5 \mu_6} + K_{\mu_1 \mu_4} K_{\mu_2 \mu_3} K_{\mu_5 \mu_6} \\ & + K_{\mu_1 \mu_2} K_{\mu_3 \mu_5} K_{\mu_4 \mu_6} + K_{\mu_1 \mu_3} K_{\mu_2 \mu_5} K_{\mu_4 \mu_6} + K_{\mu_1 \mu_5} K_{\mu_2 \mu_3} K_{\mu_4 \mu_6} \\ & + K_{\mu_1 \mu_2} K_{\mu_3 \mu_6} K_{\mu_4 \mu_5} + K_{\mu_1 \mu_3} K_{\mu_2 \mu_6} K_{\mu_4 \mu_5} + K_{\mu_1 \mu_4} K_{\mu_2 \mu_5} K_{\mu_3 \mu_6} \\ & + K_{\mu_1 \mu_5} K_{\mu_3 \mu_4} K_{\mu_2 \mu_6} + K_{\mu_1 \mu_3} K_{\mu_5 \mu_4} K_{\mu_2 \mu_6} + K_{\mu_1 \mu_4} K_{\mu_5 \mu_3} K_{\mu_2 \mu_6} \\ & + K_{\mu_5 \mu_2} K_{\mu_3 \mu_4} K_{\mu_1 \mu_6} + K_{\mu_5 \mu_3} K_{\mu_2 \mu_4} K_{\mu_1 \mu_6} + K_{\mu_5 \mu_4} K_{\mu_2 \mu_3} K_{\mu_1 \mu_6}. \end{aligned}$$

公式 (1.45) 就是 **Wick 定理**。请给它画上方框。花一点时间体会。

...

...

...

很好。现在你已是一位高斯大师。呼气，然后像 Neo 那样说：“我懂高斯积分了。”

这些矩既已成为过去，现在正适合转到下一节，学习更一般的概率分布。

1.2 概率、相关与统计，以及诸如此类的一切

上一节介绍高斯分布时，我们已简短提到期望与矩的概念。这些概念同样适用于非高斯概率分布；现在重新引入并扩展其定义，以便理解描述宽神经网络的近高斯分布。

给定 N 维随机变量 z_μ 的**概率分布** $p(z)$ ，可以通过测量 z_μ 的函数来了解其统计性质。我们把这种可测函数统称为**可观测量**，记作 $\mathcal{O}(z)$ 。可观测量的**期望值**

$$\mathbb{E}[\mathcal{O}(z)] \equiv \int d^N z p(z) \mathcal{O}(z) \quad (1.46)$$

刻画随机函数 $\mathcal{O}(z)$ 的平均值。注意，可观测量 $\mathcal{O}(z)$ 不必是标量值函数；例如，分布的二阶矩是矩阵值可观测量 $\mathcal{O}(z) = z_\mu z_\nu$ 。

从操作上说，可观测量是我们通过实验测量的量，用来连接描述 z_μ 的底层概率分布的理论模型。具体而言，实验者反复测量自然可及的可观测量，收集其统计数据，再将其与某个 $p(z)$ 理论模型算出的相应期望值预测比较。

由此很自然要问：测量可观测量 $\mathcal{O}(z)$ ，能让我们了解底层分布 $p(z)$ 的哪些信息？对于先验未知的分布，是否存在一组足以探测 $p(z)$ 的可观测量，使我们能用这些信息预测此后所有涉及 z_μ 的实验结果？

考虑一类已经遇到的可观测量，即 z_μ 的矩，或 **M 点相关函数**，其期望为⁶

$$\mathbb{E}[z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M}] = \int d^N z p(z) z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M}. \quad (1.47)$$

原则上，知道一个分布的全部 M 点相关函数，就能通过 Taylor 展开计算任意解析可观测量 $\mathcal{O}(z)$ 的期望值：

$$\begin{aligned} \mathbb{E}[\mathcal{O}(z)] &= \mathbb{E} \left[\sum_{M=0}^{\infty} \frac{1}{M!} \sum_{\mu_1, \dots, \mu_M=1}^N \frac{\partial^M \mathcal{O}}{\partial z_{\mu_1} \cdots \partial z_{\mu_M}} \bigg|_{z=0} z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M} \right] \\ &= \sum_{M=0}^{\infty} \frac{1}{M!} \sum_{\mu_1, \dots, \mu_M=1}^N \frac{\partial^M \mathcal{O}}{\partial z_{\mu_1} \cdots \partial z_{\mu_M}} \bigg|_{z=0} \mathbb{E}[z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M}], \end{aligned} \quad (1.48)$$

最后一行利用期望的线性性，把 Taylor 系数移到期望之外；这种线性性继承自 (1.46) 中积分的线性性。因而，从一切实际目的看，全部 M 点相关函数的集合完全刻画了一个概率分布。⁷

然而，用全部相关函数描述既繁琐，在操作上也不可行。为可靠估计 M 点相关函数，每次抽样时必须同时测量随机变量的 M 个分量，并把这种测量重复许多次。随着 M 增大，这项任务很快变得不切实际。事实上，如果能轻易对所有 M 完成这种测量，那么 $p(z)$ 的理论模型也就不再是有用的抽象；由 (1.48) 已经知道所有可能实验的结果，便没有什么留待预测了。

就此而言，几乎所有有用的分布都能用有限个量有效描述，从而获得简约表示。例如，考虑方差为 $K_{\mu\nu}$ 的零均值 n 维高斯分布。非零的 $2m$ 点相关函数由 Wick 定理 (1.45) 给出：

$$\mathbb{E}[z_{\mu_1} z_{\mu_2} \cdots z_{\mu_{2m}}] = \sum_{\text{所有配对}} K_{\mu_{k_1} \mu_{k_2}} \cdots K_{\mu_{k_{2m-1}} \mu_{k_{2m}}}, \quad (1.50)$$

它们完全由方差 $K_{\mu\nu}$ 的 $N(N+1)/2$ 个独立分量决定。方差本身可通过测量二点相关函数估计：

$$\mathbb{E}[z_\mu z_\nu] = K_{\mu\nu}. \quad (1.51)$$

⁶本书其余部分常使用物理学术语 M 点相关函数，而非统计学术语矩；二者含义相同，可互换使用。

⁷事实上，矩通过 Laplace 变换或 Fourier 变换给出了概率分布的对偶描述。例如，概率分布 $p(z)$ 的 Laplace 变换为

$$Z_J \equiv \mathbb{E} \left[\exp \left(\sum_{\mu} J^{\mu} z_{\mu} \right) \right] = \int \left[\prod_{\mu} dz_{\mu} \right] p(z) \exp \left(\sum_{\mu} J^{\mu} z_{\mu} \right). \quad (1.49)$$

与高斯情形一样，该积分是 $p(z)$ 的 M 点相关函数的生成函数，所以可由这些相关函数重建 Z_J 。再通过逆 Laplace 变换得到概率分布。

这与我们把该分布描述成“方差为 $K_{\mu\nu}$ 的零均值 N 维高斯分布”相一致：只需指定同一组数 $K_{\mu\nu}$ ，就能选定所指的具体分布。对零均值高斯分布，无须测量或追踪任何更高点相关函数，因为它们都由方差经 (1.50) 完全约束。

更一般地，我们希望有一种系统方法，无须进行无穷多次实验就能了解非高斯概率分布。对于近高斯分布，一组有用的可观测量是统计学家所称的**累积量**，也就是物理学家所称的**连通相关函数**。⁸ 这些量的形式定义有些繁琐且不直观，所以先从几个简单例子开始。

一阶累积量或连通一点相关函数等于完整一点相关函数：

$$\mathbb{E}[z_\mu] \big|_{\text{connected}} \equiv \mathbb{E}[z_\mu]. \quad (1.52)$$

它就是分布的均值。二阶累积量或连通二点相关函数为

$$\begin{aligned} \mathbb{E}[z_\mu z_\nu] \big|_{\text{connected}} &\equiv \mathbb{E}[z_\mu z_\nu] - \mathbb{E}[z_\mu] \mathbb{E}[z_\nu] \\ &= \mathbb{E}[(z_\mu - \mathbb{E}[z_\mu])(z_\nu - \mathbb{E}[z_\nu])] \equiv \text{Cov}[z_\mu, z_\nu], \end{aligned} \quad (1.53)$$

又称分布的协方差。注意在连通版本中，取乘积前先从随机变量 z_μ 中减去均值。量 $\widehat{\Delta}z_\mu \equiv z_\mu - \mathbb{E}[z_\mu]$ 表示随机变量围绕均值的**涨落**。直观上，这种涨落以同样的概率作正贡献或负贡献， $\mathbb{E}[\widehat{\Delta}z_\mu] = \mathbb{E}[z_\mu] - \mathbb{E}[z_\mu] = 0$ ，所以必须取乘积才能估计涨落幅度。

现在把注意力限制在变号对称 $z_\mu \rightarrow -z_\mu$ 下不变的分布；零均值高斯分布 (1.34) 就具有这一性质。重要的是，我们为描述神经网络而研究的近高斯分布也具有这种宇称对称性。对所有具备该对称性的偶分布，一切奇数阶矩和奇数点连通相关函数都为零。

在此限制下，下一个最简单的可观测量是四阶累积量或连通四点相关函数，其公式为

$$\begin{aligned} &\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] \big|_{\text{connected}} \\ &= \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] \\ &\quad - \mathbb{E}[z_{\mu_1} z_{\mu_2}] \mathbb{E}[z_{\mu_3} z_{\mu_4}] - \mathbb{E}[z_{\mu_1} z_{\mu_3}] \mathbb{E}[z_{\mu_2} z_{\mu_4}] - \mathbb{E}[z_{\mu_1} z_{\mu_4}] \mathbb{E}[z_{\mu_2} z_{\mu_3}]. \end{aligned} \quad (1.54)$$

对高斯分布，回忆 Wick 定理 (1.50)，最后三项恰好减去用于计算第一项的三对 Wick 收缩，所以

$$\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] \big|_{\text{connected}} = 0. \quad (1.55)$$

连通四点相关函数实质上按定义就在高斯分布下为零；非零值表示对高斯统计的偏离。⁹ 事实上，连通四点相关函数也许是最简单的非高斯性度量。

有了些许直觉，现在终于可以讨论第 M 阶累积量或 M 点连通相关函数的定义。为完整起见，先给出一般定义，再重新限制到宇称变换 $z_\mu \rightarrow -z_\mu$ 下对称的分布。该定义

⁸在本章之外，正如我们常说 M 点相关函数而不是矩，也将常说 M 点连通相关函数而不是累积量。当需要明确指矩而非累积量时，有时会说完整相关函数，以与连通相关函数相区别。

⁹在统计学中，单个随机变量 z 的连通四点相关函数除以方差平方作归一化后，称为超额峰度。与高斯分布相比，它自然度量分布尾部，也度量出现离群值的可能性。具体而言，正值表示尾部更肥，负值表示尾部更瘦。

是归纳式的，而且有些违反直觉：它用一阶至 M 阶连通相关函数表示第 M 阶矩：

$$\begin{aligned} & \mathbb{E}[z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M}] \\ & \equiv \mathbb{E}[z_{\mu_1} z_{\mu_2} \cdots z_{\mu_M}]|_{\text{connected}} \\ & + \sum_{\text{所有划分}} \mathbb{E}[z_{\mu_{k_1^{[1]}}} \cdots z_{\mu_{k_{\nu_1}^{[1]}}}]|_{\text{connected}} \cdots \mathbb{E}[z_{\mu_{k_1^{[s]}}} \cdots z_{\mu_{k_{\nu_s}^{[s]}}}]|_{\text{connected}}, \end{aligned} \quad (1.56)$$

其中求和遍历将 M 个变量划分为 $s > 1$ 个簇的所有方式；各簇大小为 $(\nu_1, \dots, \nu_s)$ ，相应指标为 $(k_1^{[1]}, \dots, k_{\nu_1}^{[1]}), \dots, (k_1^{[s]}, \dots, k_{\nu_s}^{[s]})$. 把第 M 阶矩分解为 M 阶及以下连通相关函数乘积之和，可见连通 M 点相关函数对应一种不能由更低阶连通相关函数表示的新相关。上面把连通四点相关函数视为非高斯性的简单度量，就是一个例子。

为了解这个抽象定义如何实际运作，再看前面的例子。首先，一点连通相关函数与均值的关系自然恢复为

$$\mathbb{E}[z_{\mu}]|_{\text{connected}} = \mathbb{E}[z_{\mu}], \quad (1.57)$$

因为无法把 $M = 1$ 个变量划分成更小部分。对 $M = 2$ ，定义 (1.56) 给出

$$\begin{aligned} \mathbb{E}[z_{\mu_1} z_{\mu_2}] &= \mathbb{E}[z_{\mu_1} z_{\mu_2}]|_{\text{connected}} + \mathbb{E}[z_{\mu_1}]|_{\text{connected}} \mathbb{E}[z_{\mu_2}]|_{\text{connected}} \\ &= \mathbb{E}[z_{\mu_1} z_{\mu_2}]|_{\text{connected}} + \mathbb{E}[z_{\mu_1}] \mathbb{E}[z_{\mu_2}]. \end{aligned} \quad (1.58)$$

重新整理，用矩表示连通二点函数，可见它等价于此此前协方差的定义 (1.53)。

现在再次限制到 $z_{\mu} \rightarrow -z_{\mu}$ 下不变的宇称对称分布，并记住所有奇数点连通相关函数均为零。对这种分布，在 $M = 4$ 时计算定义 (1.56) 得

$$\begin{aligned} \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] &= \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}]|_{\text{connected}} \\ &+ \mathbb{E}[z_{\mu_1} z_{\mu_2}]|_{\text{connected}} \mathbb{E}[z_{\mu_3} z_{\mu_4}]|_{\text{connected}} \\ &+ \mathbb{E}[z_{\mu_1} z_{\mu_3}]|_{\text{connected}} \mathbb{E}[z_{\mu_2} z_{\mu_4}]|_{\text{connected}} \\ &+ \mathbb{E}[z_{\mu_1} z_{\mu_4}]|_{\text{connected}} \mathbb{E}[z_{\mu_2} z_{\mu_3}]|_{\text{connected}}. \end{aligned} \quad (1.59)$$

均值为零时， $\mathbb{E}[z_{\mu_1} z_{\mu_2}] = \mathbb{E}[z_{\mu_1} z_{\mu_2}]|_{\text{connected}}$ ；所以这也只是将此前零均值分布的连通四点相关函数表达式 (1.54) 重新排列。

为看到新的内容，继续考察 $M = 6$ ：

$$\begin{aligned} \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\mu_5} z_{\mu_6}] &= \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\mu_5} z_{\mu_6}]|_{\text{connected}} \\ &+ \mathbb{E}[z_{\mu_1} z_{\mu_2}]|_{\text{connected}} \mathbb{E}[z_{\mu_3} z_{\mu_4}]|_{\text{connected}} \mathbb{E}[z_{\mu_5} z_{\mu_6}]|_{\text{connected}} \\ &+ [14 \text{ 个其他 } (2, 2, 2) \text{ 划分}] \\ &+ \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}]|_{\text{connected}} \mathbb{E}[z_{\mu_5} z_{\mu_6}]|_{\text{connected}} \\ &+ [14 \text{ 个其他 } (4, 2) \text{ 划分}], \end{aligned} \quad (1.60)$$

这里把完整六点相关函数写成连通二点、四点和六点相关函数乘积之和。重新排列该式，

并用定义 (1.53) 和 (1.54) 表示连通二点、四点相关函数，得到连通六点相关函数：

$$\begin{aligned}
 & \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\mu_5} z_{\mu_6}]|_{\text{connected}} \\
 &= \mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\mu_5} z_{\mu_6}] \\
 & \quad - \{\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] \mathbb{E}[z_{\mu_5} z_{\mu_6}] + [14 \text{ 个其他 } (4, 2) \text{ 划分}]\} \\
 & \quad + 2 \{\mathbb{E}[z_{\mu_1} z_{\mu_2}] \mathbb{E}[z_{\mu_3} z_{\mu_4}] \mathbb{E}[z_{\mu_5} z_{\mu_6}] + [14 \text{ 个其他 } (2, 2, 2) \text{ 划分}]\}.
 \end{aligned} \tag{1.61}$$

这种重排对计算很有用：先计算一个分布的矩，再整理所得表达式以求连通相关函数。

回到 (1.60)，容易看出高斯分布的连通六点相关函数为零。又因高斯分布的连通四点相关函数也为零，十五个 $(2, 2, 2)$ 划分项恰等于对等式左端完整相关函数施行 Wick 收缩产生的十五项。事实上，把连通相关函数的一般定义 (1.56) 用于零均值高斯分布，可归纳看出所有 $M > 2$ 的 M 点连通相关函数都为零。¹⁰ 因此，连通相关函数是衡量一个分布如何偏离高斯性的非常自然的量。

据此，终于可以把**近高斯分布**定义为所有 $M > 2$ 的连通相关函数都很小的分布。¹¹ 事实上，描述神经网络的非高斯分布通常具有如下性质：随着网络变宽，连通四点相关函数变小，而更高点的连通相关函数变得更小。对这些近高斯分布，少数几个领先的连通相关函数便能简洁而准确地描述分布，正如少数几个领先 Taylor 系数可以很好地描述函数在展开点附近的行为。

1.3 近高斯分布

现在已经通过对高斯统计的可测偏离——即很小但非零的连通相关函数——定义了近高斯分布，自然要问如何把这些可观测量与分布 $p(z)$ 的实际函数形式联系起来。这种联系可通过作用量建立。

作用量 $S(z)$ 是通过下式定义概率分布 $p(z)$ 的函数：

$$p(z) \propto e^{-S(z)}. \tag{1.62}$$

在统计学文献中，作用量 $S(z)$ 有时称为负对数概率；这里仍沿用物理学文献，称之为作用量。为了使 (1.62) 成为有意义的概率分布， $p(z)$ 必须可归一化，从而满足

$$\int d^N z p(z) = 1. \tag{1.63}$$

这正是归一化因子或**配分函数**

$$Z \equiv \int d^N z e^{-S(z)} \tag{1.64}$$

¹⁰为看清这一点，注意若所有高阶连通相关函数都为零，则定义 (1.56) 等价于 Wick 定理 (1.50)；(1.56) 中的非零项——划分为大小 $(2, \dots, 2)$ 的簇——恰好对应 (1.50) 中的各种配对。

¹¹如 §1.1 所述，方差设定高斯分布的尺度。对近高斯分布，要求所有 $2m$ 点连通相关函数相对于适当次幂的方差在参数意义下很小，即示意地说， $|\mathbb{E}[z_{\mu_1} \cdots z_{\mu_{2m}}]|_{\text{connected}} \ll |K_{\mu\nu}|^m$ 。

发挥作用的地方. 算出配分函数后, 可把特定作用量 $S(z)$ 的概率分布定义为

$$p(z) \equiv \frac{e^{-S(z)}}{Z}. \quad (1.65)$$

反过来, 给定概率分布, 可在加法歧义下为其关联作用量 $S(z) = -\log[p(z)]$: 这种歧义源于作用量的常数平移可由配分函数中的乘法因子抵消.¹²

作用量是近似某些统计过程的便利方式, 尤其适合具有近高斯统计的过程. 为说明这一点, 先从描述高斯分布的最简单作用量开始, 再展示如何系统地微扰它以纳入各种非高斯性.

二次作用量与高斯分布

我们已知高斯分布的函数形式, 直接从 (1.34) 的指数读出作用量:

$$S(z) = \frac{1}{2} \sum_{\mu, \nu=1}^N K^{\mu\nu} z_\mu z_\nu, \quad (1.66)$$

其中再提醒一次, 矩阵 $K^{\mu\nu}$ 是方差矩阵 $K_{\mu\nu}$ 的逆. 配分函数由归一化积分 (1.30) 给出; 我们已在 §1.1 中计算过该积分:

$$Z = \int d^N z e^{-S(z)} = I_K = \sqrt{|2\pi K|}. \quad (1.67)$$

这个**二次作用量**是最简单的可归一化作用量, 也是定义其他分布的起点.

下面将看到, 对高斯分布的积分是计算近高斯分布下期望的基本构件. 为区分一般期望与对高斯分布的积分, 引入特殊的左矢-右矢记号 $\langle \cdot \rangle$, 专用于计算高斯期望值. 对可观测量 $\mathcal{O}(z)$, 定义**高斯期望**

$$\langle \mathcal{O}(z) \rangle_K \equiv \frac{1}{\sqrt{|2\pi K|}} \int \left[\prod_{\mu=1}^N dz_\mu \right] \exp\left(-\frac{1}{2} \sum_{\mu, \nu=1}^N K^{\mu\nu} z_\mu z_\nu\right) \mathcal{O}(z). \quad (1.68)$$

特别地, 用该记号可将 Wick 定理写为

$$\langle z_{\mu_1} z_{\mu_2} \cdots z_{\mu_{2m}} \rangle_K = \sum_{\text{所有配对}} K_{\mu_{k_1} \mu_{k_2}} \cdots K_{\mu_{k_{2m-1}} \mu_{k_{2m}}}. \quad (1.69)$$

若讨论方差为 $K_{\mu\nu}$ 的高斯分布, 则可互换使用 $\mathbb{E}[\cdot]$ 与 $\langle \cdot \rangle_K$. 若讨论的是近高斯分布 $p(z)$, 则 $\mathbb{E}[\cdot]$ 表示相对于 $p(z)$ 的期望, 即 (1.46). 不过, 计算这种期望时常遇到高斯积分, 我们将用左矢-右矢记号 $\langle \cdot \rangle_K$ 化简表达式.

四次作用量与微扰理论

现在寻找一种作用量, 用来表示连通四点相关函数很小但不为零的近高斯分布:

$$\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}]|_{\text{connected}} = O(\epsilon). \quad (1.70)$$

¹²一种约定是选取该常数, 使作用量在其全局最小值处为零.

这里引入了小参数 $\epsilon \ll 1$, 并指出相关函数应为 ϵ 阶. 对神经网络, 稍后将发现小参数 ϵ 的角色由 $1/\text{width}$ 扮演.

给二次作用量 (1.66) 加上一个小的四次项, 形变高斯分布, 应当就能产生一个小的连通四点相关函数; 由此得到**四次作用量**

$$S(z) = \frac{1}{2} \sum_{\mu, \nu=1}^N K^{\mu\nu} z_\mu z_\nu + \frac{\epsilon}{4!} \sum_{\mu, \nu, \rho, \lambda=1}^N V^{\mu\nu\rho\lambda} z_\mu z_\nu z_\rho z_\lambda, \quad (1.71)$$

其中**四次耦合** $\epsilon V^{\mu\nu\rho\lambda}$ 是一个 $(N \times N \times N \times N)$ 维张量, 对其四个指标完全对称. 因指标对称会在求和造成重复计数, 按惯例加入因子 $1/4!$ 予以补偿. 虽然这还不能证明二者的联系, 但耦合 $\epsilon V^{\mu\nu\rho\lambda}$ 恰有足够的分量, 可忠实再现同样为 $(N \times N \times N \times N)$ 维对称张量的连通四点相关函数 (1.70). 至少从这个角度看, 我们开局不错.

下面建立四次耦合与连通四点相关函数之间的对应. 一般而言, 不可能用非高斯作用量闭式计算任何期望值——甚至配分函数也不例外. 因此, 为计算连通四点相关函数, 必须使用**微扰理论**, 把所有量展开到小参数 ϵ 的一阶; 其中每一项都能闭式求值. 这件事做起来比说起来容易, 下面开始计算.

首先计算配分函数:

$$\begin{aligned} Z &= \int \left[\prod_{\mu} dz_{\mu} \right] e^{-S(z)} \\ &= \int \left[\prod_{\mu} dz_{\mu} \right] \exp \left(-\frac{1}{2} \sum_{\mu, \nu} K^{\mu\nu} z_{\mu} z_{\nu} - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \right) \\ &= \sqrt{|2\pi K|} \left\langle \exp \left(-\frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \right) \right\rangle_K. \end{aligned} \quad (1.72)$$

第二行代入四次作用量 (1.71), 最后一行用左矢-右矢记号 (1.68) 表示方差为 $K_{\mu\nu}$ 的高斯期望. 如前所述, 最后一行的高斯期望不能闭式求值. 但因参数 ϵ 很小, 可对指数函数作 Taylor 展开, 把配分函数写成简单高斯期望之和, 再用 Wick 定理 (1.69) 求值:

$$\begin{aligned} Z &= \sqrt{|2\pi K|} \left\langle 1 - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} + O(\epsilon^2) \right\rangle_K \\ &= \sqrt{|2\pi K|} \left[1 - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} \langle z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \rangle_K + O(\epsilon^2) \right] \\ &= \sqrt{|2\pi K|} \left[1 - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} (K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + K_{\rho_1 \rho_3} K_{\rho_2 \rho_4} + K_{\rho_1 \rho_4} K_{\rho_2 \rho_3}) + O(\epsilon^2) \right] \\ &= \sqrt{|2\pi K|} \left[1 - \frac{1}{8} \epsilon \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + O(\epsilon^2) \right]. \end{aligned} \quad (1.73)$$

最后一行利用四次耦合的完全对称性, 并重命名若干求和哑指标, 把三个 K^2 项合并起来.

类似地, 计算二点相关函数:

$$\begin{aligned}
\mathbb{E}[z_{\mu_1} z_{\mu_2}] &= \frac{1}{Z} \int \left[\prod_{\mu} dz_{\mu} \right] e^{-S(z)} z_{\mu_1} z_{\mu_2} \\
&= \frac{\sqrt{|2\pi K|}}{Z} \left\langle z_{\mu_1} z_{\mu_2} \exp \left(-\frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \right) \right\rangle_K \\
&= \frac{\sqrt{|2\pi K|}}{Z} \left[\langle z_{\mu_1} z_{\mu_2} \rangle_K - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} \langle z_{\mu_1} z_{\mu_2} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \rangle_K + O(\epsilon^2) \right] \\
&= \left[1 + \frac{1}{8} \epsilon \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} \right] K_{\mu_1 \mu_2} \\
&\quad - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} (3K_{\mu_1 \mu_2} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + 12K_{\mu_1 \rho_1} K_{\mu_2 \rho_2} K_{\rho_3 \rho_4}) + O(\epsilon^2) \\
&= K_{\mu_1 \mu_2} - \frac{\epsilon}{2} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} K_{\mu_1 \rho_1} K_{\mu_2 \rho_2} K_{\rho_3 \rho_4} + O(\epsilon^2).
\end{aligned} \tag{1.74}$$

从第一行到第二行, 代入四次作用量 (1.71), 并把积分改写成高斯期望. 再把 ϵ 展开到一阶; 下一步在分母中用 (1.73) 代入配分函数 Z , 并利用 $1/(1-x) = 1+x+O(x^2)$ 把 $1/Z$ 展开到 ϵ 一阶. 同一步还注意到, 高斯期望 $\langle z_{\mu_1} z_{\mu_2} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \rangle_K$ 产生的十五项中, 有三种方式让 z_{μ_1} 与 z_{μ_2} 彼此收缩, 另有十二种方式不让它们彼此收缩. 再次利用 $V^{\rho_1 \rho_2 \rho_3 \rho_4}$ 的对称性, 这就是唯一重要的区别.

最后计算完整四点相关函数:

$$\begin{aligned}
\mathbb{E}[z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4}] &= \frac{1}{Z} \int \left[\prod_{\mu} dz_{\mu} \right] e^{-S(z)} z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} \\
&= \frac{\sqrt{|2\pi K|}}{Z} \left[\langle z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} \rangle_K - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} \langle z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \rangle_K + O(\epsilon^2) \right] \\
&= \left[1 + \frac{1}{8} \epsilon \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} \right] [K_{\mu_1 \mu_2} K_{\mu_3 \mu_4} + K_{\mu_1 \mu_3} K_{\mu_2 \mu_4} + K_{\mu_1 \mu_4} K_{\mu_2 \mu_3}] \\
&\quad - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1 \rho_2 \rho_3 \rho_4} \\
&\quad \times \left(3K_{\mu_1 \mu_2} K_{\mu_3 \mu_4} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + 12K_{\mu_1 \rho_1} K_{\mu_2 \rho_2} K_{\mu_3 \mu_4} K_{\rho_3 \rho_4} + 12K_{\mu_3 \rho_1} K_{\mu_4 \rho_2} K_{\mu_1 \mu_2} K_{\rho_3 \rho_4} \right. \\
&\quad + 3K_{\mu_1 \mu_3} K_{\mu_2 \mu_4} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + 12K_{\mu_1 \rho_1} K_{\mu_3 \rho_2} K_{\mu_2 \mu_4} K_{\rho_3 \rho_4} + 12K_{\mu_2 \rho_1} K_{\mu_4 \rho_2} K_{\mu_1 \mu_3} K_{\rho_3 \rho_4} \\
&\quad + 3K_{\mu_1 \mu_4} K_{\mu_2 \mu_3} K_{\rho_1 \rho_2} K_{\rho_3 \rho_4} + 12K_{\mu_1 \rho_1} K_{\mu_4 \rho_2} K_{\mu_2 \mu_3} K_{\rho_3 \rho_4} + 12K_{\mu_2 \rho_1} K_{\mu_3 \rho_2} K_{\mu_1 \mu_4} K_{\rho_3 \rho_4} \\
&\quad \left. + 24K_{\mu_1 \rho_1} K_{\mu_2 \rho_2} K_{\mu_3 \rho_3} K_{\mu_4 \rho_4} \right) + O(\epsilon^2).
\end{aligned} \tag{1.75}$$

从第一行到第二行, 代入四次作用量 (1.71), 展开到 ϵ 一阶, 再用左矢-右矢记号 (1.68) 改写. 第三行再次代入配分函数 Z 的表达式 (1.73), 把 $1/Z$ 展开到 ϵ 一阶, 然后用 Wick 定理 (1.69) 计算四阶与八阶高斯矩. (是的, 我们知道计算 $\langle z_{\mu_1} z_{\mu_2} z_{\mu_3} z_{\mu_4} z_{\rho_1} z_{\rho_2} z_{\rho_3} z_{\rho_4} \rangle_K$

并不好玩. 各项如何分组仍取决于 μ 类指标是否与 ρ 类指标收缩.) 注意到有些项因 $\frac{1}{8} - \frac{3}{24} = 0$ 相消, 另一些项则可利用二点相关函数 (1.74) 的表达式重新组合:

$$\begin{aligned} K_{\mu_1\mu_2}K_{\mu_3\mu_4} - \frac{\epsilon}{24} \sum_{\rho_1, \dots, \rho_4} V^{\rho_1\rho_2\rho_3\rho_4} (12K_{\mu_1\rho_1}K_{\mu_2\rho_2}K_{\mu_3\rho_3}K_{\mu_4\rho_4} + 12K_{\mu_3\rho_1}K_{\mu_4\rho_2}K_{\mu_1\rho_3}K_{\mu_2\rho_4}) \\ = \mathbb{E}[z_{\mu_1}z_{\mu_2}]\mathbb{E}[z_{\mu_3}z_{\mu_4}] + O(\epsilon^2), \end{aligned} \quad (1.76)$$

最终得到

$$\begin{aligned} \mathbb{E}[z_{\mu_1}z_{\mu_2}z_{\mu_3}z_{\mu_4}] \\ = \mathbb{E}[z_{\mu_1}z_{\mu_2}]\mathbb{E}[z_{\mu_3}z_{\mu_4}] + \mathbb{E}[z_{\mu_1}z_{\mu_3}]\mathbb{E}[z_{\mu_2}z_{\mu_4}] + \mathbb{E}[z_{\mu_1}z_{\mu_4}]\mathbb{E}[z_{\mu_2}z_{\mu_3}] \\ - \epsilon \sum_{\rho_1, \dots, \rho_4} V^{\rho_1\rho_2\rho_3\rho_4} K_{\mu_1\rho_1}K_{\mu_2\rho_2}K_{\mu_3\rho_3}K_{\mu_4\rho_4} + O(\epsilon^2). \end{aligned} \quad (1.77)$$

给定完整四点相关函数 (1.75) 与二点相关函数 (1.74), 终于可以由 (1.54) 求出连通四点相关函数:

$$\mathbb{E}[z_{\mu_1}z_{\mu_2}z_{\mu_3}z_{\mu_4}]|_{\text{connected}} = -\epsilon \sum_{\rho_1, \dots, \rho_4} V^{\rho_1\rho_2\rho_3\rho_4} K_{\mu_1\rho_1}K_{\mu_2\rho_2}K_{\mu_3\rho_3}K_{\mu_4\rho_4} + O(\epsilon^2). \quad (1.78)$$

当二者都很小时, 该式明确展示了连通四点相关函数与作用量中四次耦合的关系. 对由四次作用量 (1.71) 实现的近高斯分布, 我们看到它确实如承诺的那样近似高斯: 耦合 $\epsilon V^{\rho_1\rho_2\rho_3\rho_4}$ 的强度直接控制分布偏离高斯统计的程度, 而这一偏离由连通四点相关函数度量. 这也说明, 四指标张量 $V^{\rho_1\rho_2\rho_3\rho_4}$ 在分量 $z_{\rho_1}z_{\rho_2}z_{\rho_3}z_{\rho_4}$ 之间产生非平凡相关, 而这种相关无法仅由任意一对随机变量 $z_\mu z_\nu$ 间的相关 $K_{\mu\nu}$ 构成.

最后注意, 连通二点相关函数 (1.74)——即该近高斯分布的协方差——也会因四次耦合 $\epsilon V^{\rho_1\rho_2\rho_3\rho_4}$ 而偏离高斯值 $K_{\mu_1\mu_2}$. 因而, 近高斯形变不仅产生由连通四点相关函数 (1.78) 度量的复杂四点相关模式, 也会修改高斯二点相关的细节.

现在已经知道如何计算近高斯分布的统计性质, 不妨退一步思考为何这种计算可行. 只要问题中存在无量纲小参数 ϵ , 满足 $\epsilon \ll 1$ 但 $\epsilon > 0$, 就可以进行这些微扰计算. 因此, 只要问题具有任何极端尺度——无论小还是大——微扰理论都是极其强大的理论分析工具.

重要的是, 这与从理论上理解实际神经网络直接相关. 后续各章将说明, 真实网络有一个参数 n ——一层中的神经元数——它通常很大 $n \gg 1$, 但当然不是无穷大 $n < \infty$. 这意味着可以按大参数的倒数展开描述这类网络的分布, 即 $\epsilon = 1/n$. 事实上, 当 n 很大——实践中通常如此——描述神经网络的分布会成为近高斯分布, 因而在理论上可处理. 这种展开称为 $1/n$ 展开或大 n 展开, 将成为我们学习深度学习理论原理的主要工具之一.

旁论: 统计独立性与相互作用

四次作用量 (1.71) 是相互作用理论最简单的模型之一. 我们已把四次耦合与非零连通四点相关函数的非高斯统计联系起来, 从而显式说明了这一点. 这里尝试借助统计独立性的概念, 直观解释相互作用的含义.

回忆概率论：若两个随机变量 x 和 y 的联合分布分解为

$$p(x, y) = p(x)p(y). \quad (1.79)$$

则二者统计独立. 对高斯分布, 若方差矩阵 $K_{\mu\nu}$ 为对角矩阵, 则 z_μ 的不同分量之间毫无相关; 它们显然彼此统计独立.

即使 $K_{\mu\nu}$ 不是对角矩阵, 也仍可通过旋转到适当基底来解开高斯分布的相关. 如 §1.1 所述, 总存在正交矩阵 O , 将协方差对角化为 $(OKO^T)_{\mu\nu} = \lambda_\mu \delta_{\mu\nu}$. 用变量 $u_\mu \equiv (Oz)_\mu$ 表示, 分布为

$$p(z) = \frac{1}{\sqrt{|2\pi K|}} \exp\left(-\sum_{\mu=1}^N \frac{u_\mu^2}{2\lambda_\mu}\right) = \prod_{\mu=1}^N \left(\frac{e^{-\frac{u_\mu^2}{2\lambda_\mu}}}{\sqrt{2\pi\lambda_\mu}}\right) = p(u_1) \cdots p(u_N). \quad (1.80)$$

由此可见, 在 u 坐标基底中, 原多元高斯分布分解为 N 个统计独立的单变量高斯分布.

从作用量看, 统计独立性还表现为作用量分解成彼此分离的各项之和. 存在非零非高斯耦合时, 通常无法解开变量间的相互作用. 例如, 用于换基的正交矩阵 $O_{\mu\nu}$ 只有 $\sim N^2$ 个分量, 而使随机变量相关的四次耦合 $\epsilon V^{\mu\nu\rho\lambda}$ 有 $\sim N^4$ 个分量, 所以一般不可能把四次作用量重新表示为 N 个不同变量的函数之和. 既然作用量不能写成 N 个分离项之和, 联合分布便不能分解, 各分量也不会彼此独立. 因此, 不可能把近高斯分布分解为 N 个统计独立分布的乘积. 在此意义下, 所谓相互作用就是统计独立性的破缺.¹³

近高斯作用量

我们已通过一个具体例子说明如何形变二次作用量, 以实现最简单的近高斯分布; 现在更一般地考察近高斯分布. 下文仍要求分布在宇称对称性 $z_\mu \rightarrow -z_\mu$ 下不变. 在作用量表示中, 这对应只包含偶数次项.¹⁴

在此前提下, 除此之外相当一般地, 可以通过形变高斯作用量来表示非高斯分布:

$$S(z) = \frac{1}{2} \sum_{\mu, \nu=1}^N K^{\mu\nu} z_\mu z_\nu + \sum_{m=2}^k \frac{1}{(2m)!} \sum_{\mu_1, \dots, \mu_{2m}=1}^N s^{\mu_1 \cdots \mu_{2m}} z_{\mu_1} \cdots z_{\mu_{2m}}, \quad (1.81)$$

由于变量乘积 $z_{\mu_1} \cdots z_{\mu_{2m}}$ 的置换对称性意味着系数 $s^{\mu_1 \cdots \mu_{2m}}$ 的指标 $\mu_1, \dots, \mu_{2m}$ 对称, 按惯例加入因子 $1/(2m)!$, 以补偿求和中的重复计数. 作用量非高斯部分的项数由整数 k 控制. 若 k 无界, 则 $S(z)$ 是任意偶函数, $p(z)$ 可以是任意宇称对称分布. 当展开为多

¹³敏锐的读者也许会问: 单变量分布中 $N=1$, 没有其他变量可与之相互作用, 此时是否仍存在相互作用? 对于近高斯分布, 即使 $N=1$, 我们也在 (1.74) 中看到, 分布的方差偏离其高斯值 K , 并依赖四次耦合 ϵV . 在物理学中, 我们说这一偏移源于四次耦合 ϵV 所诱导的自相互作用; 因为与作为比较基准的自由高斯理论相比, 它改变了可观测量的值, 尽管这里不能诉诸统计独立性的概念.

换个说法, 尽管作用量只涉及一项, 这种非高斯分布的配分函数或相关函数仍没有闭式解; 也就是说, 当 $S(z) = \frac{z^2}{2K} + \frac{1}{4!} \epsilon V z^4$ 时, 并不存在能精确计算 $e^{-S(z)}$ 这类积分的技巧. 因此, 仍须用微扰理论分析这种分布中的自相互作用.

¹⁴施加这种宇称对称性, 从而使作用量中不存在奇数次项, 意味着所有奇数阶矩乃至所有奇数点连通相关函数都为零.

项式的 $S(z)$ 截断到适度小的次数 k ——例如四次作用量的 $k = 2$ ——就能很好表示所关心的统计过程时，作用量最为有用。

系数 $s^{\mu_1 \cdots \mu_{2m}}$ 通常称为**非高斯耦合**，它们控制 z_μ 的**相互作用**。¹⁵ 具体哪些 z_μ 分量一同出现在作用量的乘积中，与这些变量间连通相关的存在直接对应；(1.81) 中某项的次数会直接贡献于同阶连通相关函数。式 (1.78) 已展示一个例子，它把四次项与连通四点相关函数联系起来。这样，耦合便提供了一种非常直接的方法来控制非高斯相关的阶数和模式，而作用量的总次数则让我们能够系统地纳入越来越复杂的相关模式。

回忆 §1.2，我们把近高斯分布定义为所有这些连通相关函数都很小的分布。等价地，从作用量角度看，近高斯分布是作用量具有 (1.81) 形式的非高斯分布，并且对所有 $1 \leq m \leq k$ ，所有耦合 $s^{\mu_1 \cdots \mu_{2m}}$ 在参数意义下都很小：

$$|s^{\mu_1 \cdots \mu_{2m}}| \ll |K^{\mu\nu}|^m, \quad (1.82)$$

由于指标不匹配，该式具有一定示意性。¹⁶ 重要的是，应与逆方差或二次耦合 $K^{\mu\nu}$ 的适当次幂比较，因为如前所述，方差设定了作为这些近高斯分布比较基准的高斯分布尺度。

将在 §4 看到，宽神经网络由近高斯分布描述。具体而言，这些网络由一种特殊的近高斯分布描述，其连通相关函数按层级变小，标度为

$$\mathbb{E}[z_{\mu_1} \cdots z_{\mu_{2m}}] \Big|_{\text{connected}} = O(\epsilon^{m-1}), \quad (1.83)$$

其中同一参数 ϵ 控制各个 $2m$ 点连通相关函数的不同标度。重要的是，随着 ϵ 变小，高点连通相关函数带来的非高斯性在参数意义下变得更不重要。

这意味着，对具有层级标度 (1.83) 的近高斯分布，可以在 ϵ 的某个固定阶上一致地截断作用量以近似该分布。具体而言，可用形式为 (1.81) 的作用量忠实表示直至 $O(\epsilon^{k-1})$ 阶的全部相关，忽略 $O(\epsilon^k)$ 及更高阶的连通相关。只要 ϵ 足够小且 k 足够大，使 $O(\epsilon^k)$ 可忽略，所得作用量就为所关心的统计过程提供有用且有效的描述。

实践中，截断到 $k = 2$ 的四次作用量 (1.71) 足以建模现实的有限宽神经网络。该四次作用量抓住了近高斯分布与高斯分布之间重要的定性差异：它纳入随机变量不同分量之间的非平凡相互作用。此外，在 $O(\epsilon)$ 阶截断的近高斯分布与在 $O(\epsilon^2)$ 阶截断的近高

¹⁵类似地，作用量中的系数 $K^{\mu\nu}$ 有时称为二次耦合，因为二次作用量中分量 z_μ 与 z_ν 的耦合会产生非平凡相关，即 $\text{Cov}[z_\mu, z_\nu] = K_{\mu\nu}$ 。

¹⁶尽管如此，该示意式在量纲上是一致的。为说明这一点，简要介绍量纲分析：设随机变量 z_μ 的量纲为 ζ ，记作 $[z_\mu] = \zeta^1$ 。所谓量纲，可想成长度单位；例如把 $[z_\mu] = \zeta^1$ 读作“ z 的一个分量以 ζ 为单位度量。”具体单位是任意的：以长度为例，可选择 `meters`、`inches` 或 `parsecs`，只要使用长度单位即可；却不能使用例如 `meters`²，因为它是面积单位。重要的是，不能把具有不同单位的量相加或令其相等：把长度与面积相加在逻辑上毫无意义。这类似于计算机科学中的类型安全概念；例如，不应把类型为 `str` 的变量与类型为 `int` 的变量相加。

作用量 $S(z)$ 是指数 $p(z) \propto e^{-S(z)}$ 的宗量，所以必须无量纲；否则，指数展开 $e^{-S} = 1 - S + \frac{S^2}{2} + \dots$ 将违反刚才描述的相加规则。由作用量的无量纲要求，推知逆协方差矩阵的量纲为 $[K^{\mu\nu}] = \zeta^{-2}$ ，协方差本身的量纲为 $[K_{\mu\nu}] = \zeta^2$ 。类似地，(1.81) 中所有非高斯耦合的量纲都是 $[s^{\mu_1 \cdots \mu_{2m}}] = \zeta^{-2m}$ 。因而，(1.82) 两侧量纲相同，该式量纲一致。

更具体地，考虑四次作用量 (1.71)。若令四次耦合的张量部分量纲为 $[V^{\mu\nu\rho\lambda}] = \zeta^{-4}$ ，则参数 ϵ 如前所述是无量纲的。这意味着可一致地把 ϵ 与一比较；其参数意义下的小量性质 $\epsilon \ll 1$ 表示完整四次耦合 $\epsilon V^{\mu\nu\rho\lambda}$ 远小于二次耦合的平方，并且连通四点相关函数 (1.78) 远小于连通二点相关函数 (1.74) 的平方。

斯分布之间，统计量 (1.83) 的差异主要是定量的：两者都有非平凡的非高斯相关，但高阶相关模式仅有很小的差异，并受到 $O(\epsilon^2)$ 的压低。这样，四次作用量所表示的分布既足够复杂，能够捕捉神经网络中最显著的非高斯效应，又足够简单，可以解析处理。

第 2 章

神经网络

有人问我：“感知机今天表现如何？”
我常忍不住回答：“很好，谢谢；那么
中子和电子表现得怎样？”

Frank Rosenblatt, 感知机的发明者,
也即感知机本人 [6].

数学预备课程已经结束，现在我们转向深度学习的入门概览。

在 §2.1 中，我们将介绍神经网络架构的基本组件——神经元、激活、偏置、权重和层——并据此定义**多层感知机** (multilayer perceptron, MLP)：一种由这些基本组件迭代复合而成的简单模型。根据定义，所有深度网络都由许多结构相同的层迭代复合而成，因此在全书中，MLP 将作为说明深度学习原理的典型网络架构。这类神经网络模型既足够丰富，能够捕捉深度学习理论的一切本质方面，又足够简单，可以保持本书的教学重点。不过，我们也会简要说明如何为其他网络架构建立有效理论。

在 §2.2 中，我们列出实践中常用的一些激活函数。

最后，我们在 §2.3 中讨论 MLP 如何初始化。在那里，我们将完成一次关键的概念转变：不再把权重和偏置视为随机变量，而改为考察它们在神经活动和网络输出上诱导的分布。当我们在 §4 中开始为具有一般激活函数的 MLP 建立有效理论时，本章推导的表达式将提供自然起点。

2.1 函数逼近

人工神经网络作为受认知科学与神经科学启发的人工智能，有着丰富的历史。¹⁷ 这里，我们从讨论函数 $f(x)$ 开始。

有些函数非常简单，很容易用加、减、乘、除这些基本运算描述。例如，可以考虑恒等函数 $f(x) = x$ 或指数函数 $f(x) = e^x$ 。前者堪称平凡，因为不涉及任何运算。后者

¹⁷McCulloch 与 Pitts 于 1943 年发明了人工神经元 [7]，用它作为生物神经元的模型。他们的神经元本质上是带偏置的感知机，但没有可学习权重。Rosenblatt 于 1958 年发明了具有可学习权重的感知机模型 [8]。2012 年，人们认识到图形处理器 (GPU) 很适合训练和运行神经网络所需的并行计算，深度学习由此真正成熟起来 [9]。

是一种特殊函数，可以用许多方式定义，例如通过其 Taylor 级数

$$e^x \equiv \sum_{k=0}^{\infty} \frac{x^k}{k!}. \quad (2.1)$$

这个定义用加法、乘法和除法等基本运算构造指数函数：分子 x^k 表示变量 x 重复相乘 k 次，分母中的阶乘 $k!$ 表示整数连乘 $k! = 1 \times 2 \times \cdots \times (k-1) \times k$ 。虽然这种描述包含无穷多项之和，但用这些简单运算计算函数的实际指令 (2.1) 极其紧凑，只占大约七分之一行；在许多用途中，仅取求和的前几项便能得到 e^x 的有效近似。

另一些函数极其复杂，用基本运算描述它们时，很可能任何一本纸质书都容纳不下。例如，设函数 $f(x)$ 的输入是一幅图像 x_i ——它表示为一个数值向量，对应一幅黑白像素图——若图像描绘了一只猫，函数输出 1，否则输出 0。人类能够识别猫的图像，因此这样的分类函数理应存在；但如何用加法和乘法之类的简单运算描述它，完全不清楚。**人工智能 (AI)** 主要关注的正是这类函数：人类容易计算，却难以用基本运算描述。

表示这类难以描述的函数所需的概念跃迁，是从一组灵活的函数 $\{f(x; \theta)\}$ 出发；这些函数由简单组件构造，并由可调**模型参数**向量 θ_μ 参数化。随后，人们尝试审慎地调节模型参数 θ_μ ，使 $f(x; \theta^*) \approx f(x)$ ，从而逼近原来的复杂函数。函数集 $\{f(x; \theta)\}$ 的描述以及模型参数的设定值 θ_μ^* ，便共同构成所需函数 $f(x)$ 的一种有用近似描述。这称为**函数逼近**，而调节模型参数 θ_μ 的程序称为**学习算法**。

更具体地，把函数 $f(x)$ 的输入集合表示为由 n_0 维向量组成的集合

$$\mathcal{D} = \{x_{i;\alpha}\}_{\alpha=1, \dots, N_{\mathcal{D}}}, \quad (2.2)$$

并称其为**输入数据**。这里，**样本指标** α 标记含 $N_{\mathcal{D}}$ 个元素的数据集中的每个样本，而向量指标 $i = 1, \dots, n_0$ 标记输入向量的分量。在上面的例子中，每个数 $x_{i;\alpha}$ 指数据集 $\mathcal{D}$ 中第 α 幅图像的第 i 个像素；该数据集共有 $N_{\mathcal{D}}$ 幅图像，每幅图像可能包含猫，也可能不包含。调节模型参数 θ_μ ，使函数 $f(x; \theta^*)$ 对尽可能多的输入数据给出正确答案，我们便可以用一种不再难以言传的方式，逼近那个捉摸不定的“是猫或不是猫”函数。使用数据集 $\mathcal{D}$ 训练这类函数——而不是对它们进行编程——这一总体思想称为**机器学习**，它与传统的 von Neumann 数字计算机模型形成对照。

任何参数化函数集都可以用于函数逼近，¹⁸但我们将聚焦于一类特殊的可复合函数；它们最初源自对大脑的简化模型。这类函数起初称为**人工神经网络**，如今则简称为**神经网络**。**深度学习**是机器学习的一个分支，它用神经网络作为函数逼近器，并特别强调堆叠结构相似的许多层。下面更详细地看看它如何运作。

神经网络最基本的组件是**神经元**。人工神经元粗略地受到生物神经元行为的启发，本质上包含两个简单运算：

- 神经元的**预激活量** z_i 是输入信号 s_j 的线性汇总，其中每个信号由 W_{ij} 加权，并由 b_i 加偏置：

$$z_i(s) = b_i + \sum_{j=1}^{n_{\text{in}}} W_{ij} s_j \quad \text{for } i = 1, \dots, n_{\text{out}}. \quad (2.3)$$

¹⁸例如，考虑若干高斯函数之和，并把每个高斯函数的均值和方差作为可调参数。

- 随后，每个神经元根据经过加权和偏置处理的证据——也就是预激活量 z_i 的值——决定是否激发，并产生**激活**

$$\sigma_i \equiv \sigma(z_i) . \quad (2.4)$$

标量函数 $\sigma(z)$ 称为**激活函数**，它独立作用于预激活向量的每个分量。

这 n_{out} 个神经元合在一起构成一个**层**；该层接收 n_{in} 维信号向量 s_j ，并输出 n_{out} 维激活向量 σ_i 。从这种整体视角看，一个层由偏置向量 b_i 和权重矩阵 W_{ij} 参数化，其中 $i = 1, \dots, n_{\text{out}}$ 、 $j = 1, \dots, n_{\text{in}}$ ，同时还配有固定的激活函数 $\sigma(z)$ 。

利用这些组件，我们可以把许多神经元组织成层，并迭代堆叠许多这样的层，使一层神经元的输出激活成为另一层神经元的输入信号，从而构造愈加灵活的函数集。神经元的组织方式及其连接模式称为神经网络**架构**。以堆叠多神经元层为基本原则的典型神经网络架构称为**多层感知机**（MLP）¹⁹。

激活函数通常选为非线性函数，以提高神经网络函数 $f(x; \theta)$ 的表达能力。最简单、也是历史上最早的激活函数要么激发、要么不激发：当 $z \geq 0$ 时 $\sigma(z) = 1$ ，当 $z < 0$ 时 $\sigma(z) = 0$ 。换言之，当加权累积证据 $\sum_j W_{ij} x_j$ 超过激发阈值 $-b_i$ 时且仅当此时，每个神经元才激发。更一般地，激活函数并非二值函数，它可以在输出中纳入证据的强度。在 §2.2 中，我们会介绍深度学习中许多常用激活函数。

MLP 由下列迭代方程递归定义：

$$\begin{aligned} z_i^{(1)}(x_\alpha) &\equiv b_i^{(1)} + \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha}, \quad \text{for } i = 1, \dots, n_1, \\ z_i^{(\ell+1)}(x_\alpha) &\equiv b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma\left(z_j^{(\ell)}(x_\alpha)\right), \quad \text{for } i = 1, \dots, n_{\ell+1}; \ell = 1, \dots, L-1, \end{aligned} \quad (2.5)$$

它描述了一个含 L 个神经元层的网络，其中每层 ℓ 由 n_ℓ 个神经元组成。²⁰ 图 2.1 展示了一个 MLP 架构示例。层数 L 定义网络的**深度**，各层不同的神经元数 $n_{\ell=1, \dots, L-1}$ 定义各层的**宽度**。深度和隐藏层宽度是可变的**架构超参数**，它们定义网络的形状； n_0 与 n_L 的值则分别由函数逼近任务的输入维数和输出维数决定。特别地，网络计算出的末层预激活量

$$f(x; \theta) = z^{(L)}(x), \quad (2.6)$$

充当函数逼近器，其模型参数 θ_μ 是所有层的偏置与权重的并集。有时，把这组模型参数看成显式向量 θ_μ 会很方便；该向量的分量遍历所有模型参数。此时， θ_μ 的维数，也就是模型参数总数，为

$$P = \sum_{\ell=1}^L (n_\ell + n_\ell n_{\ell-1}), \quad (2.7)$$

¹⁹这里的“感知机”一名继承自 Rosenblatt 的感知机架构 [8]，它最初旨在模拟人类感知。感知机一词也用于指最初的阶跃激活函数；参见 §2.2 的第一项。

²⁰MLP 的一个较现代名称是全连接网络（fully-connected network, FCN），这个名称强调给定层 ℓ 中的每个神经元都与第 $\ell+1$ 层的每个神经元相连；图 2.1 清楚地展示了这一点。这种稠密连接模式要求大量架构参数，计算代价很高，应当与本节末尾介绍的更稀疏架构对照。为了强调网络的深度而不是连接的密度，本书主要采用多层感知机，而不用全连接网络这一名称。




图 2.1: 左: 一个示例多层感知机 (MLP) 架构中的神经元与连接. 这个 MLP 有 $L = 4$ 层, 定义了一组函数 $f(x; \theta)$, 输入维数为 $n_0 = 4$, 输出维数为 $n_4 = 1$. 三个隐藏层各有五个神经元, 即 $n_1 = n_2 = n_3 = 5$, 所以模型参数总数为 $P = 91$. 描述神经元连接的图是有向无环图, 这意味着信号只沿一个方向传播, 不会在网络内部形成回路. 因此, MLP 有时也称为前馈网络. 右: 每个神经元的细致结构: (i) 把偏置与加权信号相加, 产生预激活量; (ii) 由预激活量生成激活; (iii) 把激活乘以下一层权重.

它随网络宽度二次增长，并随深度线性增长。

中间层 $\ell = 1, \dots, L-1$ 称为**隐藏层**，因为这些层中神经元的预激活量和激活并非网络输出的一部分。一方面， $\ell < L$ 时的变量 $z^{(\ell)}(x)$ 只是为了构造愈加灵活的函数集而引入的临时变量；这个函数集应当具有足够强的表达能力，才有机会逼近难以描述的函数。另一方面，类比物理大脑，人们认为这些变量编码了神经网络如何进行逼近的有用信息；例如，某个神经元可能在识别出尾巴、胡须或代表皮毛的图案时激发，而这些都可能成为判断图像是否含猫的有效特征。

除了 MLP，神经网络架构的选择往往由我们试图逼近的函数的性质驱动。例如，若数据集 $\mathcal{D}$ 的性质已知且能够明确表达，就可以把**归纳偏置**构建进架构，使得到的函数集更好地表示底层函数。²¹下面看几个例子。

- 在**计算机视觉** (CV) 应用中，使用**卷积神经网络** (CNN) 或卷积网络 [9-13]，可以利用图像信息以空间局域方式组织、并且往往遵守平移不变性这一事实。²²
- 在**自然语言处理** (NLP) 应用中，**transformer** 架构（尚无缩写）用于处理序列输入——例如一段文本，或者编码蛋白质的氨基酸序列——并促使序列中任意元素之间形成相关性 [14]。模型的这一性质恰当地称为**注意力**。

这些归纳偏置的一个重要性质，是它们会在权重之间诱导约束或关系。例如，可以把卷积层视为一种特殊的 MLP 层：许多权重被设为零，其余权重的值还会由若干不同神经元共享。这一性质称为**权重绑定**。这意味着，卷积层实际上属于 MLP 层能够描述的函数类别；但若不显式施加这些约束，训练几乎不可能找到它们。只要空间局域性和平移不变性的归纳偏置成立，卷积层就会通过大幅削减需要训练和存储的权重数，获得明显的计算优势。

不论现代深度学习的具体神经网络架构中嵌入了何种归纳偏置，它们都共同采用一个思想：把神经组件组织成许多迭代层，从而构造灵活的函数集。MLP 是依赖这种堆叠思想的最简单神经网络架构，因此为**深度学习有效理论**提供了一个最小模型。具体而言，我们预期：(a) 本书揭示的深度学习理论原理具有普遍性，对基于多层神经组件堆叠思想的多种架构都成立；(b) 以本书为如何建立理论的指南，所得有效理论形式体系可以按需特化到感兴趣的具体架构。特别地，只要在适当位置把 MLP 迭代方程 (2.5) 换成其他架构的方程——例如卷积层迭代方程 (2.8)——便能在我们的形式体系中研究其他架构。当我们在 §4 中开始建立有效理论时，会指出应在何处进行这种替换。

最后，在附录 B 中，我们将研究带有残差连接的神经网络，即**残差网络**。这类架构经过特殊修改，使越来越深的网络得以训练。在该附录最后一节，我们还会说明如何把

²¹我们会在 §6、§11 和结语 ϵ 中从不同视角讨论 MLP 的归纳偏置。

²²对于二维卷积层，MLP 的迭代方程 (2.5) 被替换为

$$z_{i,(c,d)}^{(\ell+1)}(x_\alpha) \equiv b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} \sum_{c'=-k}^k \sum_{d'=-k}^k W_{ij}^{(\ell+1)} \sigma\left(z_{j,(c+c',d+d')}^{(\ell)}(x_\alpha)\right), \quad (2.8)$$

其中，在 $z_{i,(c,d)}^{(\ell)}$ 中，第一个指标 i 是辅助通道指标，成对指标 (c,d) 是二维空间指标；数 k 是各层的一个固定常数，决定卷积窗口的大小。特别地，同一组权重会用于输入的不同空间位置，这会强化图像数据往往具有平移不变性这一归纳偏置。换言之，不论猫位于图像中的什么位置，它仍然是猫。在本书写作时，卷积层是许多现代深度学习架构的关键组成部分，但未来情况可能发生变化。请予以注意。

有效理论方法扩展到一般残差网络，包括残差卷积网络（即 **ResNet**）以及 *transformer* 架构。

2.2 激活函数

本节讨论一些最常见的激活函数。这份清单并不穷尽，希望读者也不会因此精疲力尽。为方便比较，我们在图 2.2 中把所有这些激活函数画在一起。在 §5 中，我们将使用有效理论评估这些激活函数让输入信号有效穿过深层网络的相对能力。

感知机

perceptron 是最初的激活函数 [7]。它只是一个阶跃函数：

$$\sigma(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0, \end{cases} \quad (2.9)$$

这对应于计算机科学家心目中的简单性：神经元要么激发并输出 1，要么不激发并输出 0。²³

尽管逻辑上简单，它却是一种糟糕的选择。正如我们将看到的，为了让信号既能有效穿过网络 (§5 与 §9)，又能使网络得到训练 (§10)，传播关于预激活量 z 的多于一个比特的信息会很有帮助。**perceptron** 具有历史意义，但从不适用于深度神经网络。

Sigmoid

sigmoid 激活函数是 logistic 函数

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{2} + \frac{1}{2} \tanh\left(\frac{z}{2}\right), \quad (2.10)$$

它是 **perceptron** 的光滑版本。它不仅连续，还保留了关于预激活量大小的信息，不过主要是在 $z = 0$ 附近、函数近似线性的区域内。在该区域之外，**sigmoid** 会随着自身越来越接近 **perceptron** 而强烈压缩这些信息：当 $z \rightarrow \infty$ 时， $\sigma(z) \rightarrow 1$ ；当 $z \rightarrow -\infty$ 时， $\sigma(z) \rightarrow 0$ ，即发生饱和。

作为从定义域 $(-\infty, \infty)$ 到值域 $[0, 1]$ 的映射，**sigmoid** 还可以自然地解释为把对数几率转换成概率；这是它在机器学习中的主要用途。对于深度学习，**sigmoid** 的可微性对于发展训练带隐藏层神经网络的学习算法——反向传播——至关重要 [15]。不过，在深度神经网络中，**sigmoid** 激活函数仍是糟糕的选择：正如我们会在 §5 中看到的，问题源于它不经过原点。

Tanh

双曲正切，即 **tanh** 激活函数

$$\sigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} = \frac{e^{2z} - 1}{e^{2z} + 1}, \quad (2.11)$$

²³也可以平移并缩放 **perceptron**，使 $\sigma(z) = \text{sign}(z)$ 。




图 2.2: 常用激活函数 $\sigma(z)$. 横纵网格的单位分别是一个预激活量单位 z 和一个激活单位 σ . (图中未画出 leaky ReLU.)

是经输入、输出缩放并平移后的 sigmoid；这从 (2.10) 可以清楚看出。尤其重要的是，它经过平移后满足 $\sigma(0) = 0$ [16]。

除 ReLU 或下面将讨论的类 ReLU 激活函数外， $\tanh$ 或许是最流行的激活函数；可以说，它还是最流行的光滑激活函数。作为光滑激活函数的典范， $\tanh$ 在本书中对我们尤为重要。

Sin

$\sin$ 激活函数正如其名：

$$\sigma(z) = \sin(z), \quad (2.12)$$

也就是三个标准三角函数之一。周期非线性函数长期以来一直在流行与退潮之间循环，参见例如 [17]；不过它们从未真正流行起来。

尺度不变：线性、ReLU 与 leaky ReLU

尺度不变激活函数是满足下式的任意激活函数：

$$\sigma(\lambda z) = \lambda \sigma(z), \quad (2.13)$$

其中 λ 是任意正缩放因子。之所以称其尺度不变，是因为预激活量的任意缩放 $z \rightarrow \lambda z$ 都可以由激活的反向缩放 $\sigma(z) \rightarrow \lambda^{-1} \sigma(z)$ 抵消。满足这一条件的恰好²⁴是如下形式的激活函数：

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0. \end{cases} \quad (2.14)$$

尺度不变激活函数包括 **linear** ($a_+ = a_- = a$)、修正线性单元 ReLU ($a_+ = 1$ 、 $a_- = 0$) [18, 19]，以及 **leaky ReLU** ($a_+ = 1$ 、 $a_- = a$) [20]。ReLU 是深度神经网络中最常用的激活函数，因此也是本书重点研究的对象。

为加深对尺度不变性的理解，考察其他激活函数如何破坏它。以 $\tanh$ 激活函数 $\sigma(z) = \tanh(z)$ 为例。在数学上，除非 $\lambda = 1$ ，否则 $\tanh(\lambda z) \neq \lambda \tanh(z)$ ，所以 $\tanh$ 违反尺度不变性。特别地，激活函数在小预激活量处近似线性，即 $|z| \ll 1$ 时 $\tanh(z) \approx z$ ；但在大预激活量处会饱和，即 $|z| \gg 1$ 时 $|\tanh(z)| \approx 1$ 。因此， $\tanh$ 带有内禀交叉尺度 $|z| \sim 1$ ，它分隔了这两个区域。从图 2.2 可以直观看到这一点：若把视野拉远，所有非尺度不变激活函数——例如 **perceptron**、**sigmoid** 与 $\tanh$ ——都会显得被压扁，而尺度不变激活函数——例如 ReLU 与 **linear**——在任何尺度上看起来都相同。

最后注意，除名称恰如其分的 **linear** 激活外，所有尺度不变激活函数都会因原点 $z = 0$ 处的折点，在网络输入与输出之间建立非线性关系。堆叠许多采用这些非线性激活函数的神经元层会累积非线性，使深度神经网络能够表示高度非线性的函数。

²⁴为证明必要性，先对尺度不变方程 (2.13) 关于 z 求导，得到任意 $\lambda > 0$ 下 $\sigma'(\lambda z) = \sigma'(z)$ 。随后注意，这要求 $z > 0$ 时导数为常数 a_+ ， $z < 0$ 时导数为另一个常数 a_- 。最后，要满足 (2.13)，还必须满足 $\lim_{z \rightarrow \pm 0} \sigma(z) = 0$ 。证毕。

类 ReLU: softplus、SWISH 与 GELU

尽管 ReLU 很流行，人们仍会对它不光滑这一事实感到不安。为改善这种状况，人们提出了多种光滑化的类 ReLU 激活函数，其中一些得到一定程度的采用；我们考察如下三种：

- softplus 激活函数 [21]

$$\sigma(z) = \log(1 + e^z), \quad (2.15)$$

在大正自变量 $z \gg 1$ 下呈线性行为 $\sigma(z) \approx z$ ，在负自变量下则以指数方式趋零，即 $z < 0$ 时 $\sigma(z) \approx e^{-|z|}$ 。重要的是，softplus 不经过原点： $\sigma(0) = \log(2)$ 。

- SWISH 激活函数 [22] 定义为

$$\sigma(z) = \frac{z}{1 + e^{-z}}, \quad (2.16)$$

即 logistic 函数 (2.10) 乘以预激活量 z 。logistic 函数充当连续的开关，因此 SWISH 逼近 ReLU；回忆一下，ReLU 定义为离散开关乘以预激活量 z 。特别地， $z > 0$ 时 SWISH 表现为 $\sigma(z) \approx z$ ，而 $z < 0$ 时表现为 $\sigma(z) \approx 0$ 。与 z 相乘还保证 SWISH 经过原点，即 $\sigma(0) = 0$ 。

- Gaussian Error Linear Unit (GELU) 激活函数 [23] 与 SWISH 很相似，其表达式为

$$\sigma(z) = \left[\frac{1}{2} + \frac{1}{2} \operatorname{erf}\left(\frac{z}{\sqrt{2}}\right) \right] \times z, \quad (2.17)$$

其中，误差函数 $\operatorname{erf}(z)$ 定义为

$$\operatorname{erf}(z) \equiv \frac{2}{\sqrt{\pi}} \int_0^z dt e^{-t^2}, \quad (2.18)$$

即高斯函数的部分积分。特别地， $\operatorname{erf}(z)$ 的图像与 $\tanh(z)$ 十分相似，因此 GELU 定义中使用的缩放和平移版本 $\frac{1}{2} + \frac{1}{2} \operatorname{erf}\left(\frac{z}{\sqrt{2}}\right)$ ，其图像与 logistic 函数 (2.10) 的图像十分相似。与 SWISH 一样，它经过原点，而且沿任一方向离 0 越远，就越接近 ReLU。

在对 ReLU 进行光滑化时，这三个激活函数都引入了内禀尺度，并违反尺度不变性条件 (2.13)。

2.3 系综

正如在 §2.1 中讨论的，神经网络是经过训练的，而不是被编程的。从实践上说，要开始训练一个用于函数逼近的神经网络，我们需要设定偏置 $b_i^{(\ell)}$ 和权重 $W_{ij}^{(\ell)}$ 的初值。由于模型参数的学习值几乎总是在其初值上迭代累积而成，初始化策略会对函数逼近的成败产生重大影响。

也许最简单的策略是把所有偏置和权重都设为零，即 $b_i^{(\ell)} = W_{ij}^{(\ell)} = 0$ 。然而，这种初始化无法打破隐藏层 ℓ 中 n_ℓ 个不同神经元之间的置换对称性。如果该对称性没有被

打破，各个神经元所执行的计算完全相同，我们便无法区分同一层中的不同神经元。实际上，网络的行为将如同每个隐藏层都只有一个神经元，即 $n_\ell = 1$ 。因此，要利用较宽网络中偏置和权重的所有不同分量，就必须以某种方式打破置换对称性。

能够打破这一置换对称性的最简单策略，或许是从某个概率分布中独立采样每个偏置和权重。从理论上说，我们应当选择这样的**初始化分布**，使由此得到的网络**系综**对于函数逼近任务具有良好行为。本节将为分析这种系综做好初始化准备。

偏置与权重的初始化分布

在众多可能合理的初始化分布中，最自然的选择是高斯分布。²⁵正如前面讨论的，高斯分布完全由均值与方差定义，因此在理论上易于规定和处理。从中采样也极其容易，而这同样是实践中选择采样分布时的关键考虑。

具体而言，在初始化 MLP 时，我们将分别从零均值高斯分布中独立采样每个偏置和每个权重，其方差为

$$\mathbb{E} \left[b_{i_1}^{(\ell)} b_{i_2}^{(\ell)} \right] = \delta_{i_1 i_2} C_b^{(\ell)}, \quad (2.19)$$

$$\mathbb{E} \left[W_{i_1 j_1}^{(\ell)} W_{i_2 j_2}^{(\ell)} \right] = \delta_{i_1 i_2} \delta_{j_1 j_2} \frac{C_W^{(\ell)}}{n_{\ell-1}}. \quad (2.20)$$

这里的 Kronecker delta 表明，各个偏置和权重均彼此独立地抽取。这些高斯分布的显式函数形式为

$$p(b_i^{(\ell)}) = \frac{1}{\sqrt{2\pi C_b^{(\ell)}}} \exp \left[-\frac{1}{2C_b^{(\ell)}} (b_i^{(\ell)})^2 \right], \quad (2.21)$$

$$p(W_{ij}^{(\ell)}) = \sqrt{\frac{n_{\ell-1}}{2\pi C_W^{(\ell)}}} \exp \left[-\frac{n_{\ell-1}}{2C_W^{(\ell)}} (W_{ij}^{(\ell)})^2 \right]. \quad (2.22)$$

这里，权重方差中的 $1/n_{\ell-1}$ 归一化纯属约定；但正如我们将在 §3 和 §4 中明确说明的，它对于宽神经网络是必要的，而且在比较不同宽度网络的行为时很自然。²⁶还要注意，我们允许偏置方差 $C_b^{(\ell)}$ 和重标度权重方差 $C_W^{(\ell)}$ 随层变化。偏置方差集合 $\{C_b^{(1)}, \dots, C_b^{(L)}\}$ 与重标度权重方差集合 $\{C_W^{(1)}, \dots, C_W^{(L)}\}$ 合称**初始化超参数**。有效理论方法的一项实际成果，将是给出这些初始化超参数的设定方案，使神经网络输出具有良好行为。

²⁵实践中还可见另外两种初始化分布：均匀分布和截断正态分布。对于权重，在均值设为零、方差设为相等时，宽网络中高斯分布与任何其他分布的差异受到 $1/\text{width}$ 抑制。换言之，由于中心极限定理，最终真正重要的只有权重初始化分布的一阶矩与二阶矩，即均值和方差。因而不妨直接使用高斯分布。对于偏置，高斯分布与其他分布之间的差异在实践中大多无关紧要，因为我们会发现，对所有良好的激活函数都应令偏置方差 $C_b^{(\ell)}$ 为零。

²⁶这一约定可以追溯到 MLP 迭代方程 (2.5)。为计算预激活量 $z_{i;\alpha}^{(\ell)} = b_i^{(\ell)} + \sum_{j=1}^{n_{\ell-1}} W_{ij}^{(\ell)} \sigma_{j;\alpha}^{(\ell-1)}$ ，我们实质上把 $n_{\ell-1}$ 个随机权重相加。当 $n_{\ell-1}$ 很大时，方差中的归一化因子 $1/n_{\ell-1}$ ——等价于把每个权重按 $1/\sqrt{n_{\ell-1}}$ 归一化——恰好抵消许多零均值随机数求和的效应。偏置不涉及这种求和，因而不需要相应的归一化因子。

诱导分布

给定由 $N_{\mathcal{D}}$ 个输入数据组成的数据集 $\mathcal{D} = \{x_{i;\alpha}\}$, 在 $\mathcal{D}$ 上计算、模型参数为 $\theta_{\mu} = \{b_i^{(\ell)}, W_{ij}^{(\ell)}\}$ 的 MLP 会输出一个 $n_L \times N_{\mathcal{D}}$ 的数值阵列

$$f_i(x_{\alpha}; \theta) = z_i^{(L)}(x_{\alpha}) \equiv z_{i;\alpha}^{(L)}, \quad (2.23)$$

它同时由**神经元指标** $i = 1, \dots, n_L$ 与**样本指标** $\alpha = 1, \dots, N_{\mathcal{D}}$ 标记. 每次从初始化分布 $p(\theta)$ 中抽取模型参数 θ_{μ} 并实例化一个 MLP, 都会得到一组不同的初始输出 $z_{i;\alpha}^{(L)}$. 因而, 既然初始化时的偏置 $b_i^{(\ell)}$ 和权重 $W_{ij}^{(\ell)}$ 是随机变量, 网络输出 $z_{i;\alpha}^{(L)}$ 也必然是随机变量. 初始化分布由此在网络输出上诱导出一个分布.

这一**输出分布** $p(z^{(L)}|\mathcal{D})$ 控制初始化点处网络输出的统计性质. 实践中, 该分布的性质与网络通过反复调节模型参数来逼近目标函数的难易程度直接相关; 因此, 从实践者的视角看, 控制这一分布极为重要. 从理论家的视角看, 模型参数的初始化分布虽然被刻意设计得很简单, 由它诱导出的输出分布却并不简单. 在理论上, 我们需要计算对所有模型参数的如下巨型积分:

$$p(z^{(L)}|\mathcal{D}) = \int \left[\prod_{\mu=1}^P d\theta_{\mu} \right] p(z^{(L)}|\theta, \mathcal{D}) p(\theta). \quad (2.24)$$

在英勇地计算这个积分之前, 请注意, 被积式 (2.24) 中的条件分布 $p(z^{(L)}|\theta, \mathcal{D})$ 实际上是确定性的. 换言之, 只要知道输入集合 $\mathcal{D}$ 和全部模型参数 θ_{μ} 的设定, 就知道如何计算网络输出: 只需使用定义 MLP 的迭代方程 (2.5). 我们尚不知道的是, 如何用—个分布表达这种确定性.

确定性分布与 Dirac delta 函数

什么样的概率分布是确定性的? 抽象地把这种分布记为 $p(z|s) = \delta(z|s)$, 意在编码确定性关系 $z = s$. 这一分布应具有什么性质? 首先, z 的均值应为 s :

$$\mathbb{E}[z] = \int dz \delta(z|s) z \equiv s. \quad (2.25)$$

其次, 由于关系是确定性的, 方差应当为零. 换言之,

$$\mathbb{E}[z^2] - (\mathbb{E}[z])^2 = \left[\int dz \delta(z|s) z^2 \right] - s^2 \equiv 0, \quad (2.26)$$

或者等价地,

$$\int dz \delta(z|s) z^2 \equiv s^2. \quad (2.27)$$

事实上, 这种确定性意味着一个更强的条件. 对 z 的任意函数 $f(z)$, 其期望都应取值为 $f(s)$:

$$\mathbb{E}[f(z)] = \int dz \delta(z|s) f(z) \equiv f(s), \quad (2.28)$$

当 $f(z) = z$ 与 $f(z) = z^2$ 时, 它分别包含性质 (2.25) 与 (2.27); 当 $f(z) = 1$ 时, 还包含概率归一化条件

$$\int dz \delta(z|s) = 1. \quad (2.29)$$

²⁷事实上, (2.28) 正是 **Dirac delta 函数** 的定义性质.²⁸

不过, 作为一种表示, (2.28) 即便对我们而言也有些过于抽象. 上面的讨论却为一种具体得多的表示铺平了道路. Dirac delta 函数是均值为 s (2.25)、方差为零 (2.26) 的归一化分布 (2.29); 因此, 考虑均值为 s (1.9) 的归一化高斯分布, 并令其方差 K 趋于零:

$$\delta(z|s) \equiv \lim_{K \rightarrow +0} \frac{1}{\sqrt{2\pi K}} e^{-\frac{(z-s)^2}{2K}}. \quad (2.30)$$

该分布在 $z = s$ 处形成无限尖峰, 在其他各处趋于零, 因此, 把任意函数 $f(z)$ 与 (2.30) 相乘后积分, 并取极限, 都会得到 $f(s)$. 换言之, 它满足 Dirac delta 函数的定义性质 (2.28).

式 (2.30) 中的极限总应在把分布与某个函数相乘并积分之后再取. 即便如此, 这个表示仍可能让你有些不安, 因为它依旧是一个高度奇异的极限. 下面尝试修正这一点, 寻找更好的表示. 这里有一个魔术: 从 (2.30) 出发, 在右边插入“1”, 得到

$$\begin{aligned} \delta(z|s) &= \lim_{K \rightarrow +0} \frac{1}{\sqrt{2\pi K}} e^{-\frac{(z-s)^2}{2K}} \left\{ \frac{1}{\sqrt{2\pi/K}} \int_{-\infty}^{\infty} d\Lambda \exp \left[-\frac{K}{2} \left(\Lambda - \frac{i(z-s)}{K} \right)^2 \right] \right\} \\ &= \lim_{K \rightarrow +0} \frac{1}{2\pi} \int_{-\infty}^{\infty} d\Lambda \exp \left[-\frac{1}{2} K \Lambda^2 + i\Lambda(z-s) \right], \end{aligned} \quad (2.31)$$

其中, 花括号内插入的是对哑变量 Λ 的积分; 被积函数是方差为 $1/K$ 、虚均值为 $i(z-s)/K$ 的归一化高斯分布. 第二行只是把指数项合并起来. 现在可以容易地取 $K \rightarrow +0$ 极限, 得到 Dirac delta 函数的积分表示

$$\delta(z|s) = \frac{1}{2\pi} \int_{-\infty}^{\infty} d\Lambda e^{i\Lambda(z-s)} \equiv \delta(z-s). \quad (2.32)$$

最后一个表达式中, 我们指出该函数只依赖于差 $z-s$. 这一积分表示会在 §4 中派上上场.

²⁷满足 $\mathbb{E}[f(z)] = f(\mathbb{E}[z])$ 的随机变量称为自平均的, 意思是期望运算与函数求值的次序可以交换. 条件 (2.28) 等价于说, 分布 $\delta(z|s)$ 是自平均的.

²⁸Dirac delta 函数实际上是连续变量上 Kronecker delta (1.26) 的推广. 这里还必须给出惯例性的免责声明: 尽管名称如此, Dirac delta 函数是一个分布, 而不是函数; 从上面的讨论中, 这一点本应已经很清楚. 不过, 我们仍将遵循通行惯例, 继续称它为 *Dirac delta 函数*.

再论诱导分布

现在已经熟悉 Dirac delta 函数，我们可以用它更具体地表达输出分布 (2.24)。首先，对于深度 $L = 1$ 的单层网络，第一层输出 (2.5) 的分布为

$$p(z^{(1)}|\mathcal{D}) = \int \left[\prod_{i=1}^{n_1} db_i^{(1)} p(b_i^{(1)}) \right] \left[\prod_{i=1}^{n_1} \prod_{j=1}^{n_0} dW_{ij}^{(1)} p(W_{ij}^{(1)}) \right], \quad (2.33)$$

$$\times \left[\prod_{i=1}^{n_1} \prod_{\alpha \in \mathcal{D}} \delta \left(z_{i;\alpha}^{(1)} - b_i^{(1)} - \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha} \right) \right], .$$

这里需要 $n_1 \times N_{\mathcal{D}}$ 个 Dirac delta 函数，分别对应 $z_{i;\alpha}^{(1)}$ 的每个分量。我们将在 §4.1 中显式计算上述积分；不过，如果你已经等不及了，尽可以现在自行计算。顺便再引入 (2.33) 的一个近亲：

$$p(z^{(\ell+1)}|z^{(\ell)}) = \int \left[\prod_{i=1}^{n_{\ell+1}} db_i^{(\ell+1)} p(b_i^{(\ell+1)}) \right] \left[\prod_{i=1}^{n_{\ell+1}} \prod_{j=1}^{n_{\ell}} dW_{ij}^{(\ell+1)} p(W_{ij}^{(\ell+1)}) \right], \quad (2.34)$$

$$\times \left[\prod_{i=1}^{n_{\ell+1}} \prod_{\alpha \in \mathcal{D}} \delta \left(z_{i;\alpha}^{(\ell+1)} - b_i^{(\ell+1)} - \sum_{j=1}^{n_{\ell}} W_{ij}^{(\ell+1)} \sigma(z_{j;\alpha}^{(\ell)}) \right) \right], ,$$

它在积掉模型参数之后，给出以第 ℓ 层预激活量为条件的第 $(\ell + 1)$ 层预激活量分布。

更一般地，对于任意参数化模型，若输出为 $z_{i;\alpha}^{\text{out}} \equiv f_i(x_{\alpha}; \theta)$ ，其中 $i = 1, \dots, n_{\text{out}}$ ，且模型参数 θ_{μ} 服从 $p(\theta)$ ，则输出分布 (2.24) 可以用 Dirac delta 函数写成

$$p(z^{\text{out}}|\mathcal{D}) = \int \left[\prod_{\mu=1}^P d\theta_{\mu} \right] p(\theta) \left[\prod_{i=1}^{n_{\text{out}}} \prod_{\alpha \in \mathcal{D}} \delta(z_{i;\alpha}^{\text{out}} - f_i(x_{\alpha}; \theta)) \right]. \quad (2.35)$$

我们的预训练正是为了让自己做好计算 MLP 中这一积分的准备。

第 3 章

初始化时深度线性网络的有效理论

...一个具有球对称性的系统...当然不可能产生像马这样并不具有球对称性的生物体.

Alan Turing, 论玩具模型的局限性 [24].

在最后一个热身章节中, 我们将介绍并求解一个深度学习玩具模型: **深度线性网络**.²⁹正如 §3.1 将要说明的, 深度线性网络就是采用 `linear` 激活函数的 MLP. 特别地, 这种网络只能计算输入的线性变换, 当然不可能产生像人类这样的函数; 经验已经表明, 人类是非线性的. 尽管如此, 对深度线性网络的研究将为后续章节中更一般地发展的深度学习有效理论提供有用蓝图. 具体而言, 本章的练习会以非常直观的方式展示, 逐层递推如何控制深度神经网络的统计性质, 同时避免陷入全部技术细节.

为此, 我们在 §3.2 中得到并精确求解深度线性网络预激活量二点相关子的逐层递推. 结果突显出, 网络统计性质对初始化超参数的设定非常敏感, 而且敏感性随深度呈指数增长. 这引出临界性这一重要概念; 我们将在 §5 中以更大的深度与敏感度继续研究它. 简言之, 为使网络具有良好行为, 这些超参数必须得到精细调节.

接下来, 在 §3.3 中, 我们得到并求解四点相关子的逐层递推; 为进一步简化代数, 只考虑单个输入. 这展示了网络行为如何依赖架构超参数, 尤其是网络的宽度与深度. 此外, 我们把四点连通相关子解释为: 对模型参数进行不同次抽样时, 网络函数涨落大小的一种度量. 这类涨落会干扰初始化超参数的调节, 必须加以控制, 才能使典型抽样得到的网络可靠地运行. 涨落的尺度由网络深宽比设定, 凸显出 MLP 分析中的这一重要涌现尺度. 我们将看到, 只要让网络深宽比足够小, 就能使涨落保持受控.

最后, 在 §3.4 中, 我们对在单个输入上计算的深度线性网络, 得到任意 M 点相关子的递推. 对任何宽度 n 和深度 L , 这些递推都可以精确求解, 因而能够完全确定网络初始化时的统计性质.³⁰借助这些非微扰解, 我们分别取固定深度的大宽度极限与固定宽度的大深度极限, 并明确展示这两个极限不可交换. 我们还构造一个宽度和深度都很大、但深宽比 L/n 固定的插值解, 并考察这一尺度如何充当微扰参数, 控制网络中的全部

²⁹给物理学家一个类比: 深度线性网络之于深度学习, 正如简谐振子之于量子力学.

³⁰这里的求解不应与求解某一特定学习算法的训练动力学混淆. 对于深度线性网络, [25] 已分析了梯度下降动力学. 在 §10 和 §∞ 中, 我们将在有效理论形式体系内求解具有一般激活函数的 MLP 的梯度下降训练动力学.

相互作用以及微扰分析的有效性.

3.1 深度线性网络

深度线性网络通过一系列简单线性变换, 迭代地变换输入 $x_{i;\alpha}$:

$$z_{i;\alpha}^{(\ell+1)} = b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} z_{j;\alpha}^{(\ell)}, \quad (3.1)$$

其中 $z_{i;\alpha}^{(0)} \equiv x_{i;\alpha}$, 且 $z_{i;\alpha}^{(\ell)} \equiv z_i^{(\ell)}(x_\alpha)$. 由于 linear 激活函数就是恒等函数 $\sigma(z) = z$, 这里无需区分预激活量与激活.

本章把全部偏置关闭, 即令 $b_i^{(\ell)} = 0$, 从而略微简化问题. 此时, 第 ℓ 层的预激活量只是权重矩阵的反复矩阵乘积:

$$z_{i;\alpha}^{(\ell)} = \sum_{j_0=1}^{n_0} \sum_{j_1=1}^{n_1} \cdots \sum_{j_{\ell-1}=1}^{n_{\ell-1}} W_{ij_{\ell-1}}^{(\ell)} W_{j_{\ell-1}j_{\ell-2}}^{(\ell-1)} \cdots W_{j_1j_0}^{(1)} x_{j_0;\alpha} \equiv \sum_{j=1}^{n_0} \mathcal{W}_{ij}^{(\ell)} x_{j;\alpha}. \quad (3.2)$$

这里引入了一个 $n_\ell \times n_0$ 矩阵

$$\mathcal{W}_{ij}^{(\ell)} = \sum_{j_1=1}^{n_1} \cdots \sum_{j_{\ell-1}=1}^{n_{\ell-1}} W_{ij_{\ell-1}}^{(\ell)} W_{j_{\ell-1}j_{\ell-2}}^{(\ell-1)} \cdots W_{j_1j}^{(1)}, \quad (3.3)$$

它突显出第 ℓ 层的预激活量只是输入的线性变换. 再令 $C_W^{(\ell)} \equiv C_W$, 使权重方差的 $\mathcal{O}(1)$ 部分与层无关. 综合起来, 这意味着权重上的初始化分布由下列期望刻画:

$$\mathbb{E} [W_{ij}^{(\ell)}] = 0, \quad \mathbb{E} [W_{i_1j_1}^{(\ell)} W_{i_2j_2}^{(\ell)}] = \delta_{i_1i_2} \delta_{j_1j_2} \frac{C_W}{n_{\ell-1}}. \quad (3.4)$$

有些违反直觉的是, 一般而言, 深度线性网络表示的函数集合比完全一般的线性变换更小; 后者也就是具有相同输入、输出维数的单层网络.³¹ 作为一个极端例子, 考虑一个两层深度线性网络: 第一隐藏层只有一个神经元 $n_1 = 1$, 并考察第二层 $\ell = 2$ 的网络输出. 在这种情况下, 输入中的全部信息都先通过一个瓶颈压缩成第一层中的单个数, 再在输出层转化为 n_2 维向量. 只要 $n_0, n_2 > 1$, 这种深度线性网络所表示的线性变换子空间, 显然远小于全部 $n_2 \times n_0$ 矩阵给出的线性变换空间.

更重要的是, 我们将表明, 深度线性网络初始化时的统计性质也与单层网络非常不同. 每个 $W_{ij}^{(\ell)}$ 的统计由简单的高斯分布给出, 但其乘积 $\mathcal{W}_{ij}^{(\ell)}$ 的统计却是非高斯的, 并以复杂方式依赖网络深度 ℓ 与宽度 $n_1, \dots, n_\ell$.

本章余下部分的目标, 是精确求出这种依赖. 具体而言, 我们要计算预激活量的非平凡分布

$$p(z^{(\ell)} | \mathcal{D}) \equiv p(z^{(\ell)}(x_1), \dots, z^{(\ell)}(x_{N_{\mathcal{D}}})) , \quad (3.5)$$

³¹ 这未必是坏事, 因为聚焦于特化函数类别往往兼具计算与表征优势. 例如, 我们已经看到, 卷积网络表示的函数集比 MLP 小得多; 但由于其遵守平移不变性的归纳偏置, 并且稀疏连接模式显著降低了计算量, 它们在计算机视觉任务上表现得更好. 不过, 与一般线性变换相比, 深度线性网络是否具有有用的归纳偏置并不明显.

其中 $z_{i;\alpha}^{(\ell)} \equiv z_i^{(\ell)}(x_\alpha)$ 由在整个数据集 $\mathcal{D}$ 上计算的迭代乘积 (3.2) 所诱导. 正如 §1.2 所述, 一个分布完全由其全部 M 点相关子的集合确定; 因此, 我们确定 $p(z^{(\ell)}|\mathcal{D})$ 的方法, 就是直接计算这些相关子.

进入下一节之前, 先考察最简单的可观测量: 预激活量 $z_{i;\alpha}^{(\ell)}$ 的均值. 对定义式 (3.2) 取期望, 很容易看出任意层的平均预激活量都为零:

$$\begin{aligned}\mathbb{E}[z_{i;\alpha}^{(\ell)}] &= \sum_{j_0=1}^{n_0} \sum_{j_1=1}^{n_1} \cdots \sum_{j_{\ell-1}=1}^{n_{\ell-1}} \mathbb{E}\left[W_{ij_{\ell-1}}^{(\ell)} W_{j_{\ell-1}j_{\ell-2}}^{(\ell-1)} \cdots W_{j_1j_0}^{(1)} x_{j_0;\alpha}\right] \\ &= \sum_{j_0=1}^{n_0} \sum_{j_1=1}^{n_1} \cdots \sum_{j_{\ell-1}=1}^{n_{\ell-1}} \mathbb{E}\left[W_{ij_{\ell-1}}^{(\ell)}\right] \mathbb{E}\left[W_{j_{\ell-1}j_{\ell-2}}^{(\ell-1)}\right] \cdots \mathbb{E}\left[W_{j_1j_0}^{(1)}\right] x_{j_0;\alpha} = 0,\end{aligned}\quad (3.6)$$

因为各权重矩阵彼此独立, 也与输入独立, 并且具有零均值 (3.4). 类似地, 很容易看出预激活量的任意奇数点相关子也为零. 因此, 从现在开始, 我们只需关心偶数点相关子.

3.2 临界性

由于均值是平凡的, 接下来考察二点相关子 $\mathbb{E}\left[z_{i_1;\alpha_1}^{(\ell)} z_{i_2;\alpha_2}^{(\ell)}\right]$. 它是下一个最简单且可能有趣的可观测量, 刻画预激活量的典型大小. 我们先讨论数学, 再讨论物理.

数学: 二点相关子的递推

先从第一层的二点相关子慢慢入手. 利用定义式 (3.2), 把第一层预激活量用输入表示为

$$z_{i;\alpha}^{(1)} = \sum_j^{n_0} W_{ij}^{(1)} x_{j;\alpha}, \quad (3.7)$$

便可将二点相关子写成

$$\begin{aligned}\mathbb{E}\left[z_{i_1;\alpha_1}^{(1)} z_{i_2;\alpha_2}^{(1)}\right] &= \sum_{j_1, j_2=1}^{n_0} \mathbb{E}\left[W_{i_1j_1}^{(1)} x_{j_1;\alpha_1} W_{i_2j_2}^{(1)} x_{j_2;\alpha_2}\right] \\ &= \sum_{j_1, j_2=1}^{n_0} \mathbb{E}\left[W_{i_1j_1}^{(1)} W_{i_2j_2}^{(1)}\right] x_{j_1;\alpha_1} x_{j_2;\alpha_2} \\ &= \sum_{j_1, j_2=1}^{n_0} \frac{C_W}{n_0} \delta_{i_1i_2} \delta_{j_1j_2} x_{j_1;\alpha_1} x_{j_2;\alpha_2} = \delta_{i_1i_2} C_W \frac{1}{n_0} \sum_{j=1}^{n_0} x_{j;\alpha_1} x_{j;\alpha_2}.\end{aligned}\quad (3.8)$$

从第二行到第三行, 我们对两个权重作了 Wick 缩并, 并代入方差 (3.4). 此外, 引入记号

$$G_{\alpha_1\alpha_2}^{(0)} \equiv \frac{1}{n_0} \sum_{i=1}^{n_0} x_{i;\alpha_1} x_{i;\alpha_2}, \quad (3.9)$$

表示两个输入的内积, 并用输入维数 n_0 将其归一化. 借助这一对象, 可将第一层二点相关子 (3.8) 改写为

$$\mathbb{E}\left[z_{i_1;\alpha_1}^{(1)} z_{i_2;\alpha_2}^{(1)}\right] = \delta_{i_1i_2} C_W G_{\alpha_1\alpha_2}^{(0)}. \quad (3.10)$$

接下来，我们当然可以机械地重复同一计算：利用定义式 (3.2) 把 $z_{i;\alpha}^{(\ell)}$ 写成输入的函数，从而得到任意层的二点相关子。不过，为练习递推方法，我们改为递推地计算二点相关子。具体而言，归纳假设第 ℓ 层二点相关子已知，再由此导出第 $(\ell+1)$ 层二点相关子。在偏置为零时使用迭代方程 (3.1)，得到

$$\begin{aligned}\mathbb{E} \left[z_{i_1;\alpha_1}^{(\ell+1)} z_{i_2;\alpha_2}^{(\ell+1)} \right] &= \sum_{j_1, j_2=1}^{n_\ell} \mathbb{E} \left[W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} z_{j_1;\alpha_1}^{(\ell)} z_{j_2;\alpha_2}^{(\ell)} \right] \\ &= \sum_{j_1, j_2=1}^{n_\ell} \mathbb{E} \left[W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \right] \mathbb{E} \left[z_{j_1;\alpha_1}^{(\ell)} z_{j_2;\alpha_2}^{(\ell)} \right] \\ &= \delta_{i_1 i_2} C_W \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[z_{j;\alpha_1}^{(\ell)} z_{j;\alpha_2}^{(\ell)} \right].\end{aligned}\quad (3.11)$$

从第一行到第二行，我们利用了第 $(\ell+1)$ 层权重 $W^{(\ell+1)}$ 与第 ℓ 层预激活量 $z^{(\ell)}$ 统计独立这一事实；从第二行到第三行，我们对两个权重作 Wick 缩并并代入方差 (3.4)。注意，在任意一层，二点相关子都正比于 Kronecker delta $\delta_{i_1 i_2}$ ；除非两个神经元指标 i_1 与 i_2 相同，否则它就为零。据此，将二点相关子分解为

$$\mathbb{E} \left[z_{i_1;\alpha_1}^{(\ell)} z_{i_2;\alpha_2}^{(\ell)} \right] \equiv \delta_{i_1 i_2} G_{\alpha_1 \alpha_2}^{(\ell)}, \quad (3.12)$$

并把上述记号 (3.9) 推广到任意层 ℓ 。以 $\delta_{i_1 i_2}$ 乘上此式，对 $i_1, i_2 = 1, \dots, n_\ell$ 求和，再除以 n_ℓ ，还可把 $G_{\alpha_1 \alpha_2}^{(\ell)}$ 写成

$$G_{\alpha_1 \alpha_2}^{(\ell)} = \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[z_{j;\alpha_1}^{(\ell)} z_{j;\alpha_2}^{(\ell)} \right]. \quad (3.13)$$

因而，它可以理解为第 ℓ 层预激活量的平均内积除以该层神经元数 n_ℓ 。这个内积只依赖样本指标，因此可将 $G_{\alpha_1 \alpha_2}^{(\ell)} \equiv G^{(\ell)}(x_{\alpha_1}, x_{\alpha_2})$ 解释为两个输入 x_{α_1} 与 x_{α_2} 通过一个 ℓ 层深度线性网络后的协方差。

引入并充分解释这些记号之后，很容易看出，上面的递推 (3.11) 可以紧凑地概括为

$$G_{\alpha_1 \alpha_2}^{(\ell+1)} = C_W G_{\alpha_1 \alpha_2}^{(\ell)}, \quad (3.14)$$

它描述协方差 $G_{\alpha_1 \alpha_2}^{(\ell)}$ 如何逐层演化。显然，要把协方差从第 ℓ 层推进到第 $\ell+1$ 层，只需乘以常数 C_W 。初始条件 $G_{\alpha_1 \alpha_2}^{(0)}$ 由两个输入的内积 (3.9) 给出，其解为指数形式

$$G_{\alpha_1 \alpha_2}^{(\ell)} = (C_W)^\ell G_{\alpha_1 \alpha_2}^{(0)}, \quad (3.15)$$

这正是反复进行矩阵乘法时的典型结果。注意，权重方差 (3.4) 中的宽度因子 n_ℓ 恰好消去了，说明这确实是方差的正确标度方式。

物理：临界性

分析进行到这里，已经展示了一个有趣而且非常普遍的现象。考察解 (3.15)，一般会出现两种情况之一。若 $C_W > 1$ ，协方差将指数爆炸，对所有输入对都迅速流向固定点

$G_{\alpha_1\alpha_2}^* = \infty$ ，并导致网络输出发散。若 $C_W < 1$ ，协方差则指数衰减，对所有输入对都迅速流向固定点 $G_{\alpha_1\alpha_2}^* = 0$ ，很快抹去网络输出对数据的依赖。只要一个可观测量以指数速度趋近某个值，我们就把这个极限值称为**平凡固定点**。与 $C_W > 1$ 对应的 $G_{\alpha_1\alpha_2}^* = \infty$ ，以及与 $C_W < 1$ 对应的 $G_{\alpha_1\alpha_2}^* = 0$ ，都是平凡固定点的典型例子。

进一步考察这个问题。首先，对给定输入 $x_{i;\alpha}$ ，输出层 L 的协方差对角部分估计了输出的典型大小：

$$G_{\alpha\alpha}^{(L)} = \mathbb{E} \left[\frac{1}{n_L} \sum_{j=1}^{n_L} \left(z_{j;\alpha}^{(L)} \right)^2 \right]. \quad (3.16)$$

着眼于这一可观测量，上述指数行为应当立即敲响警钟：它意味着某种数值不稳定性 ($C_W > 1$)，或者信息丢失 ($C_W < 1$)。另外，网络输出不同分量的目标值通常是 $O(1)$ 的数，既非指数大也非指数小。因此，网络的这种指数行为会使学习逼近期望函数变得极其困难。从这个意义上说，这种协方差爆炸与消失问题，正是声名狼藉的梯度爆炸与消失问题的幼年版本；后者是深度网络基于梯度训练时的著名障碍，我们将在 §9 中作出更精确的说明。

不过，前面的分析其实略显仓促：如果把权重方差 C_W 调节到恰好等于 1，会发生什么？这显然是初始化超参数空间中的一个特殊点，将指数增长解与指数衰减解分隔开来。回到递推式 (3.14)，可见若 $C_W = 1$ ，协方差便固定为 $G_{\alpha_1\alpha_2}^{(\ell)} = G_{\alpha_1\alpha_2}^{(0)} \equiv G_{\alpha_1\alpha_2}^*$ ；即便输入数据通过多层深度线性网络，它的完整协方差也得到显式保留。这是货真价实的**非平凡固定点**，因为它不会以指数方式把输入数据的结构平凡化。因此，至少在这种启发式分析层面，为以数值稳定的方式保留输入数据结构，选择 $C_W = 1$ 似乎至关重要。更一般而言，流向非平凡固定点似乎是深度网络发挥任何有用作用的必要条件。

当我们精细调节网络的初始化超参数，使协方差避免指数行为时，就把它称为**临界初始化超参数**。³² 对于深度线性网络，临界初始化超参数 $C_W = 1$ 分隔两个区域： $C_W > 1$ 时协方差指数增长， $C_W < 1$ 时协方差指数衰减。当把权重方差调至临界值 $C_W = 1$ 时，网络的协方差具有完美的自相似性，在逐层演化过程中被精确保留。

在 §5 中，我们会把对**临界性**的分析推广到采用任意特定激活函数的 MLP。此外，正如后续 §10 和 §∞ 将要说明的，要使任何深度网络行为良好并完成有用任务，把网络调到临界性都是关键的——至少在不借助其他特别技巧来保证信号稳定传播时如此。

3.3 涨落

回顾 §1：若一个分布是零均值高斯分布，那么协方差就完全确定了这个分布。如果预激活量分布 $p(z^{(\ell)} | \mathcal{D})$ 是高斯的，那么只需把唯一的初始化超参数临界调节为 $C_W = 1$ ，就足以保证任意可观测量行为良好。然而，如果 $p(z^{(\ell)} | \mathcal{D})$ 不是高斯分布，就无法预先断定依赖高阶连通相关子的可观测量能否在同一调节下行为良好。原则上，这些可观测

³²这一用词源于统计物理中临界现象的类比。例如，考虑一个由铁制成的磁体这一原型例子。在高温下，铁原子的磁矩——或者说自旋——指向随机方向，形成没有相干磁场的顺磁相。相反，在低温下，各自旋会试图集体朝同一方向排列，形成具有相干磁场的铁磁相——可以想象儿童玩耍的 $\cap$ 形卡通磁铁。一个临界温度将磁性的这两个相分隔开来；处于临界温度的磁体将呈现一种既非顺磁性也非铁磁性、称为自相似性的非常特殊行为。

量可能要求对 C_W 作其他调节, 而这些调节或许与协方差 $G_{\alpha_1\alpha_2}^{(\ell)}$ 的临界设定 $C_W = 1$ 不相容. 为解决这个问题, 我们来考察下一个最简单的可观测量: 连通四点相关子. 与前面一样, 先讨论数学, 再讨论物理.

本节及下一节为简化代数, 只考察在单个输入 $x_\alpha = x$ 上计算的预激活量相关子. 这足以定性地凸显高阶相关子的重要性, 同时避免一些烦琐技术操作的干扰. 因此, 在这两节中, 我们省略预激活量的样本指标, 并把协方差记作

$$G_2^{(\ell)} \equiv G_{\alpha\alpha}^{(\ell)} = G^{(\ell)}(x, x). \quad (3.17)$$

下一章将讨论完全一般的情形.

数学: 四点相关子的递推

与上一节处理二点相关子相同, 我们先算出第一层的四点相关子, 再导出并求解更深层相关子的递推. 对第一层, 在省略样本指标后使用定义式 (3.7), 得到完整四点相关子

$$\begin{aligned} & \mathbb{E} \left[z_{i_1}^{(1)} z_{i_2}^{(1)} z_{i_3}^{(1)} z_{i_4}^{(1)} \right] \\ &= \sum_{j_1, j_2, j_3, j_4=1}^{n_0} \mathbb{E} \left[W_{i_1 j_1}^{(1)} W_{i_2 j_2}^{(1)} W_{i_3 j_3}^{(1)} W_{i_4 j_4}^{(1)} \right] x_{j_1} x_{j_2} x_{j_3} x_{j_4} \\ &= \frac{C_W^2}{n_0^2} \sum_{j_1, j_2, j_3, j_4=1}^{n_0} (\delta_{i_1 i_2} \delta_{j_1 j_2} \delta_{i_3 i_4} \delta_{j_3 j_4} + \delta_{i_1 i_3} \delta_{j_1 j_3} \delta_{i_2 i_4} \delta_{j_2 j_4} + \delta_{i_1 i_4} \delta_{j_1 j_4} \delta_{i_2 i_3} \delta_{j_2 j_3}) x_{j_1} x_{j_2} x_{j_3} x_{j_4} \\ &= C_W^2 (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \left(G_2^{(0)} \right)^2. \end{aligned} \quad (3.18)$$

从第二行到第三行, 我们对四个权重的两次 Wick 缩并取了三种不同配对, 再用权重方差 (3.4) 计算每次缩并. 到最后一行时, 我们完成对 j 指标的求和, 并代入内积定义 (3.9); 对单个输入, 它就是

$$G_2^{(0)} = \frac{1}{n_0} \sum_{j=1}^{n_0} x_j x_j. \quad (3.19)$$

将结果 (3.18) 与第一层二点相关子 (3.10) 比较可见, 如果预激活量分布恰为高斯分布, 完整四点相关子正应取这个结果. 因此, 至少在四点相关子层面的分析中, 深度线性网络经过一层后似乎就是高斯的.³³

这种高斯性在更深层中并不成立. 为说明这一点, 我们导出并求解四点相关子的递

³³下一章将非常一般地证明, 第一层的预激活量分布总是高斯分布.

推. 从零偏置的迭代方程 (3.1) 出发, 得到

$$\begin{aligned}
& \mathbb{E} \left[z_{i_1}^{(\ell+1)} z_{i_2}^{(\ell+1)} z_{i_3}^{(\ell+1)} z_{i_4}^{(\ell+1)} \right] \\
&= \sum_{j_1, j_2, j_3, j_4=1}^{n_\ell} \mathbb{E} \left[W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \right] \mathbb{E} \left[z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_3}^{(\ell)} z_{j_4}^{(\ell)} \right] \\
&= \frac{C_W^2}{n_\ell^2} \sum_{j_1, j_2, j_3, j_4=1}^{n_\ell} (\delta_{i_1 i_2} \delta_{j_1 j_2} \delta_{i_3 i_4} \delta_{j_3 j_4} + \delta_{i_1 i_3} \delta_{j_1 j_3} \delta_{i_2 i_4} \delta_{j_2 j_4} + \delta_{i_1 i_4} \delta_{j_1 j_4} \delta_{i_2 i_3} \delta_{j_2 j_3}) \\
&\quad \times \mathbb{E} \left[z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_3}^{(\ell)} z_{j_4}^{(\ell)} \right] \\
&= C_W^2 (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \frac{1}{n_\ell^2} \sum_{j, k=1}^{n_\ell} \mathbb{E} \left[z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)} \right].
\end{aligned} \tag{3.20}$$

第二行利用了第 $(\ell + 1)$ 层权重与第 ℓ 层预激活量的独立性; 第三行再次对四个权重的两对 Wick 缩并取三种不同配对; 最后一行则适当地利用 Kronecker delta 合并求和.

从这个递推可见, 在任意一层, 完整四点相关子都正比于因子

$$(\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}).$$

这一固定张量结构规定了相关子对神经元指标的依赖. 因而, 把完整四点相关子分解为

$$\mathbb{E} \left[z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} z_{i_3}^{(\ell)} z_{i_4}^{(\ell)} \right] \equiv (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) G_4^{(\ell)}, \tag{3.21}$$

就能把全部层依赖都装入较简单的对象 $G_4^{(\ell)}$, 在递推中不再操心神经元指标. 用这种分解, 第一层相关子的结果 (3.18) 变为

$$G_4^{(1)} = C_W^2 \left(G_2^{(0)} \right)^2, \tag{3.22}$$

而上述递推 (3.20) 中最后一个因子可以改写成

$$\frac{1}{n_\ell^2} \sum_{j, k=1}^{n_\ell} \mathbb{E} \left[z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)} \right] = \frac{1}{n_\ell^2} \sum_{j, k=1}^{n_\ell} (\delta_{jj} \delta_{kk} + \delta_{jk} \delta_{jk} + \delta_{jk} \delta_{kj}) G_4^{(\ell)} = \left(1 + \frac{2}{n_\ell} \right) G_4^{(\ell)}. \tag{3.23}$$

借助此式, 整个递推 (3.20) 可简写成 $G_4^{(\ell)}$ 的递推

$$G_4^{(\ell+1)} = C_W^2 \left(1 + \frac{2}{n_\ell} \right) G_4^{(\ell)}. \tag{3.24}$$

以 (3.22) 给出的初始条件求解这一递推, 得到简单解

$$\begin{aligned}
G_4^{(\ell)} &= C_W^{2\ell} \left[\prod_{\ell'=1}^{\ell-1} \left(1 + \frac{2}{n_{\ell'}} \right) \right] \left(G_2^{(0)} \right)^2 \\
&= \left[\prod_{\ell'=1}^{\ell-1} \left(1 + \frac{2}{n_{\ell'}} \right) \right] \left(G_2^{(\ell)} \right)^2,
\end{aligned} \tag{3.25}$$

最后一行代入了协方差解 (3.15). 现在从这个紧凑公式中提取一些物理.

物理：大 n 展开、非高斯性、相互作用与涨落

首先注意，在每个隐藏层的神经元数趋于无穷 ($n_\ell \rightarrow \infty$) 的极限下，四点相关子 (3.25) 会大幅简化. 在此极限中，解 (3.25) 退化为

$$G_4^{(\ell)} = \left(G_2^{(\ell)}\right)^2, \quad (3.26)$$

而完整四点相关子 (3.21) 变为

$$\mathbb{E} \left[z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} z_{i_3}^{(\ell)} z_{i_4}^{(\ell)} \right] = (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \left(G_2^{(\ell)}\right)^2. \quad (3.27)$$

这恰好就是预激活量分布为高斯分布时的结果：四点相关子完全由二点相关子确定，而张量结构由 Wick 定理确定. 事实上，下一章将证明：对于采用任意特定非线性激活函数的任意 MLP，在这一无限宽极限中，预激活量分布都服从高斯统计；这意味着在该极限下神经元之间没有相互作用. 然而，尽管大型科技公司能为机器学习问题投入相当庞大的计算资源，现实中的 MLP 每层根本没有无穷多个神经元. 为理解现实的 MLP，我们必须离开无限宽极限.

为最清楚地说明这一点，令所有隐藏层宽度相等，即 $n_1 = n_2 = \dots = n_{L-1} \equiv n$. 计算 (3.25) 后，四点相关子统计对无限宽极限的偏离由下式编码：

$$\begin{aligned} G_4^{(\ell)} - \left(G_2^{(\ell)}\right)^2 &= \left[\left(1 + \frac{2}{n}\right)^{\ell-1} - 1 \right] \left(G_2^{(\ell)}\right)^2 \\ &= \frac{2(\ell-1)}{n} \left(G_2^{(\ell)}\right)^2 + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (3.28)$$

最后一行关于 $1/n$ 展开，并保留了相对于无限宽极限的领头修正.³⁴ 特别是在 $G_2^{(\ell)}$ 为常数的临界性处，领头修正 (3.28) 与宽度成反比、与深度成正比. 因此，对无限宽的偏离正比于网络的深宽比；这是我们首次遇到这一重要**涌现尺度**. 对这一有限宽修正有多种理解方式.

第一，连通四点相关子 (1.54) 为

$$\mathbb{E} \left[z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} z_{i_3}^{(\ell)} z_{i_4}^{(\ell)} \right] \Big|_{\text{connected}} = (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \left[G_4^{(\ell)} - \left(G_2^{(\ell)}\right)^2 \right], \quad (3.29)$$

它把差值 (3.28) 与分布非高斯性的度量直接联系起来. 可见非高斯性随网络加深而增长；只要涌现尺度——深宽比——在微扰意义下保持很小，第 ℓ 层的预激活量统计就是近高斯的. 从作用量的角度看，这意味着四次耦合会随着我们考察预激活量分布的层发生改变——或者说发生**跑动**——并且耦合与层数 ℓ 成正比增长.

第二，我们在 §1.3 中还把非零连通四点相关子解释为不同随机向量分量之间相互作用——即统计独立性的破缺——的度量. 具体考察连通四点相关子张量的一个分量：令 $i_1 = i_2 = j$ 、 $i_3 = i_4 = k$ ，且 $j \neq k$. 该分量可写成

$$\mathbb{E} \left[\left(z_j^{(\ell)} z_j^{(\ell)} - G_2^{(\ell)} \right) \left(z_k^{(\ell)} z_k^{(\ell)} - G_2^{(\ell)} \right) \right] = G_4^{(\ell)} - \left(G_2^{(\ell)}\right)^2, \quad \text{其中 } j \neq k. \quad (3.30)$$

³⁴只要网络深度没有增长得过大，这一近似就有效. 下一节将分析这个极限如何失效.

这表明，特定神经元 j 上 $z_j^{(\ell)} z_j^{(\ell)}$ 相对其均值 $\mathbb{E} [z_j^{(\ell)} z_j^{(\ell)}] = G_2^{(\ell)}$ 的偏离，与另一个神经元 k 上相对均值的同类偏离相关。因此，可把有限宽差值 (3.28) 解释为控制不同神经元之间的层内相互作用，而且相互作用强度随深度增长。

第三，一些在无限宽极限中确定的可观测量，会在有限宽下开始涨落。为此考察简单可观测量

$$\mathcal{O}^{(\ell)} \equiv \mathcal{O}(z^{(\ell)}) \equiv \frac{1}{n} \sum_{j=1}^n z_j^{(\ell)} z_j^{(\ell)}, \quad \text{其中 } \ell < L, \quad (3.31)$$

对于网络权重的某一实现，它刻画给定隐藏层 ℓ 中所有不同神经元预激活量的平均大小。对权重不同实现取平均，得到期望

$$\mathbb{E} [\mathcal{O}^{(\ell)}] = \frac{1}{n} \sum_{j=1}^n \mathbb{E} [z_j^{(\ell)} z_j^{(\ell)}] = G_2^{(\ell)}, \quad (3.32)$$

而该可观测量随实现变化的涨落大小由其方差度量：

$$\begin{aligned} \mathbb{E} [(\mathcal{O}^{(\ell)} - \mathbb{E} [\mathcal{O}^{(\ell)}])^2] &= \frac{1}{n^2} \sum_{j,k=1}^n \mathbb{E} [z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)}] - \left(G_2^{(\ell)}\right)^2 \\ &= \frac{1}{n^2} \sum_{j,k=1}^n (\delta_{jj} \delta_{kk} + \delta_{jk} \delta_{jk} + \delta_{jk} \delta_{kj}) G_4^{(\ell)} - \left(G_2^{(\ell)}\right)^2 \\ &= \frac{2}{n} G_4^{(\ell)} + \left[G_4^{(\ell)} - \left(G_2^{(\ell)}\right)^2 \right], \\ &= \frac{2\ell}{n} \left(G_2^{(\ell)}\right)^2 + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (3.33)$$

最后一步使用了有限宽差值的展开 (3.28)。正如预期， $\mathcal{O}^{(\ell)}$ 在无限宽时是确定的，因为该方差受 $1/n$ 抑制，并在无限宽极限中恒等于零。然而，离开无限宽极限后，由于有限宽修正 (3.28)，临界性处的方差会随深度线性增长。因此，随着深度增加，涨落会变大；这意味着在深度线性网络的任一给定实现上测得的预激活量典型大小 $\mathcal{O}^{(\ell)}$ ，可能进一步偏离均值 $\mathbb{E} [\mathcal{O}^{(\ell)}] = G_2^{(\ell)}$ 。

所有这些有限宽效应——无论是非高斯性、层内相互作用还是有限宽涨落——都正比于网络的深宽比。这也许是全书最重要、反复出现的主题：尽管临界性处的领头有限宽贡献受层宽的倒数抑制，它仍随深度线性增长。只要网络至少有一个隐藏层，其深度就有下界 $L \geq 2$ ——也就是说，这类网络至少有一个隐藏层和一个输出层——因此在实践中，任何有限大小的网络都会在其输出分布中表现出一定程度的有限宽效应，且该效应正比于深宽比 L/n 。后面将在 §5 中看到，对于采用任意特定激活函数的网络，这一涌现标度在临界性处都非常普遍地成立。

因此，网络越深，由于有限宽涨落的累积，无限宽高斯描述就越不适用。这其实是件好事，因为正如 §11 将进一步强调的，无限宽网络的同层神经元之间不存在相关，也无法从输入数据学习非平凡表征。实际使用的、真正有用的深度学习系统既具有这种相关，也能学习这种表征；后续分析将表明，更深的网络有能力更充分地做到这两点。

不过，深度是一把双刃剑。当网络总深度 L 与其隐藏层宽度相当时，涨落会开始占据主导。特别是，这种极深网络的可观测量会因具体实现不同而发生巨大变化。因此，

即使选择临界初始化超参数 $C_W = 1$ ，信号也会在一些实现中爆炸、在另一些实现中衰减，只有极少数实现能把信号控制在一阶大小。从实践角度看，这些网络相当无用。

从理论家的角度看，这组情况其实非常幸运：由于微扰大宽度展开适用，当网络的深宽比 L/n 很小但非零时，我们的深度学习有效理论最准确；而恰恰在这种架构超参数设定下，网络的实际表现最好。事实上，正如我们已经看到深度线性网络的初始化超参数 C_W 存在正确调节一样，为学习特征而采用非零深度的收益，与涨落增长的代价之间的平衡，可能会为采用特定激活函数的 MLP 确定某个最优深宽比 L/n 。在接下来的两章 §4 与 §5 中，我们先针对任意激活函数重新分析临界性与涨落；随后在 §6 讨论归纳偏置时，再回到 L/n 的调节问题。特别地，我们将在这两章中理解预激活量统计如何随深度跑动，并看到深宽比如何涌现为控制微扰 $1/n$ 展开有效性的尺度，就像这里的深度线性网络一样。

一般而言，在微扰论有效的区域内，有限宽修正随深度线性增长——而不是指数增长——网络仍保持良好行为。相反，当深宽比变大时，微扰论失效，使这种网络很难分析。然而，在深度线性网络这一特殊情形中，可以进行非微扰分析。下一节将明确展示，当深宽比变得非常大时，深度线性网络会发生什么，从而直观描绘网络在该区域中的行为方式。

3.4 混沌

前两节中，我们用 Wick 缩并方法导出了深度线性网络二点与四点相关子的递推，并轻松求解了它们。现在，我们将用同一方法计算所有高阶相关子，从而完成确定完整分布 $p(z^{(\ell)} | \mathcal{D})$ 的目标。为先简化代数，再专注于这一分布的有趣性质，我们仍只在单个输入 $x_\alpha = x$ 上计算相关子，并在以下所有方程中省略样本指标。还是先数学，后物理。

数学：六点及高阶相关子的递推

从第一层开始，计算一般的 $2m$ 点完整相关子。这里涉及许多 Wick 缩并，不妨翻回 §1.1，查看 (1.45)，回想一下 Wick 定理的正式表述……很好。

现在利用定义式 (3.7)，把第一层预激活量用输入表示，得到

$$\begin{aligned}
 & \mathbb{E} \left[z_{i_1}^{(1)} z_{i_2}^{(1)} \cdots z_{i_{2m-1}}^{(1)} z_{i_{2m}}^{(1)} \right] \\
 &= \sum_{j_1, \dots, j_{2m}=1}^{n_0} \mathbb{E} \left[W_{i_1 j_1}^{(1)} W_{i_2 j_2}^{(1)} \cdots W_{i_{2m-1} j_{2m-1}}^{(1)} W_{i_{2m} j_{2m}}^{(1)} \right] x_{j_1} x_{j_2} \cdots x_{j_{2m-1}} x_{j_{2m}} \\
 &= \left(\sum_{\text{所有配对}} \delta_{i_{k_1} i_{k_2}} \cdots \delta_{i_{k_{2m-1}} i_{k_{2m}}} \right) C_W^m \left(G_2^{(0)} \right)^m \\
 &= \left(\sum_{\text{所有配对}} \delta_{i_{k_1} i_{k_2}} \cdots \delta_{i_{k_{2m-1}} i_{k_{2m}}} \right) \left(G_2^{(1)} \right)^m.
 \end{aligned} \tag{3.34}$$

与前面一样，我们用 Wick 定理确定 Wick 缩并，再以 (3.4) 中的方差计算每次缩并. 这里对 $2m$ 个辅助指标 $k_1, \dots, k_{2m}$ 的所有可能配对求和，共得到 $(2m-1)!!$ 个不同项；最后一行代入第一层协方差的解 (3.15).

结果 (3.34) 证实了上一节的猜测：第一层预激活量分布完全是高斯分布. 如果观察之下还不明显，也很容易直接验证——基本上只需同样应用 Wick 定理——相关子 (3.34) 正是零均值、方差为 $\delta_{i_1 i_2} G_2^{(1)}$ 的高斯分布的 $2m$ 点相关子. 换言之，第一层的预激活量分布由二次作用量

$$S(z^{(1)}) = \frac{1}{2G_2^{(1)}} \sum_{i=1}^{n_1} z_i^{(1)} z_i^{(1)}. \quad (3.35)$$

控制.

在给出一般 $2m$ 点相关子的递推之前，先详细算出六点相关子的递推. 从偏置为零的迭代方程 (3.1) 出发，得到

$$\begin{aligned} & \mathbb{E} \left[z_{i_1}^{(\ell+1)} z_{i_2}^{(\ell+1)} z_{i_3}^{(\ell+1)} z_{i_4}^{(\ell+1)} z_{i_5}^{(\ell+1)} z_{i_6}^{(\ell+1)} \right] \\ &= \sum_{j_1, j_2, j_3, j_4, j_5, j_6=1}^{n_\ell} \mathbb{E} \left[W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} W_{i_5 j_5}^{(\ell+1)} W_{i_6 j_6}^{(\ell+1)} \right] \mathbb{E} \left[z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_3}^{(\ell)} z_{j_4}^{(\ell)} z_{j_5}^{(\ell)} z_{j_6}^{(\ell)} \right] \\ &= C_W^3 \left(\delta_{i_1 i_2} \delta_{i_3 i_4} \delta_{i_5 i_6} + \delta_{i_1 i_3} \delta_{i_2 i_4} \delta_{i_5 i_6} + \delta_{i_1 i_4} \delta_{i_2 i_3} \delta_{i_5 i_6} \right. \\ &\quad + \delta_{i_1 i_2} \delta_{i_3 i_5} \delta_{i_4 i_6} + \delta_{i_1 i_3} \delta_{i_2 i_5} \delta_{i_4 i_6} + \delta_{i_1 i_5} \delta_{i_2 i_3} \delta_{i_4 i_6} \\ &\quad + \delta_{i_1 i_2} \delta_{i_3 i_4} \delta_{i_5 i_6} + \delta_{i_1 i_5} \delta_{i_2 i_4} \delta_{i_3 i_6} + \delta_{i_1 i_4} \delta_{i_2 i_5} \delta_{i_3 i_6} \\ &\quad + \delta_{i_1 i_5} \delta_{i_3 i_4} \delta_{i_2 i_6} + \delta_{i_1 i_3} \delta_{i_5 i_4} \delta_{i_2 i_6} + \delta_{i_1 i_4} \delta_{i_5 i_3} \delta_{i_2 i_6} \\ &\quad \left. + \delta_{i_5 i_2} \delta_{i_3 i_4} \delta_{i_1 i_6} + \delta_{i_5 i_3} \delta_{i_2 i_4} \delta_{i_1 i_6} + \delta_{i_5 i_4} \delta_{i_2 i_3} \delta_{i_1 i_6} \right) \frac{1}{n_\ell^3} \sum_{i, j, k=1}^{n_\ell} \mathbb{E} \left[z_i^{(\ell)} z_i^{(\ell)} z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)} \right]. \end{aligned} \quad (3.36)$$

这里再次使用了第 $(\ell+1)$ 层权重与第 ℓ 层预激活量的独立性. 最后一行表明，六个权重的三次 Wick 缩并共有十五种不同方式.

正如四点相关子的情形，完整六点相关子的神经元指标结构在任意一层都相同，并正比于一个常张量，也就是上面括号内那一长串 Kronecker delta. 这提示我们把六点相关子分解为

$$\mathbb{E} \left[z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} z_{i_3}^{(\ell)} z_{i_4}^{(\ell)} z_{i_5}^{(\ell)} z_{i_6}^{(\ell)} \right] \equiv (\delta_{i_1 i_2} \delta_{i_3 i_4} \delta_{i_5 i_6} + \dots + \delta_{i_5 i_4} \delta_{i_2 i_3} \delta_{i_1 i_6}) G_6^{(\ell)}, \quad (3.37)$$

其中，复杂的 Kronecker delta 乘积之和囊括了对神经元指标的依赖，而层依赖完全由 $G_6^{(\ell)}$ 承担.

为了求出 $G_6^{(\ell)}$ 的递推，需要在代入分解 (3.37) 后计算

$$\frac{1}{n_\ell^3} \sum_{i, j, k=1}^{n_\ell} \mathbb{E} \left[z_i^{(\ell)} z_i^{(\ell)} z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)} \right]. \quad (3.38)$$

在给定的神经元指标模式下，求和中其实只有三类项. 具体而言，有一个形如

$$\frac{1}{n_\ell^3} \sum_{i, j, k=1}^{n_\ell} \delta_{ii} \delta_{jj} \delta_{kk} = 1 \quad (3.39)$$

的项, 六个形如

$$\frac{1}{n_\ell^3} \sum_{i,j,k=1}^{n_\ell} \delta_{ij} \delta_{ji} \delta_{kk} = \frac{1}{n_\ell} \quad (3.40)$$

的项, 以及八个形如

$$\frac{1}{n_\ell^3} \sum_{i,j,k=1}^{n_\ell} \delta_{ij} \delta_{jk} \delta_{ki} = \frac{1}{n_\ell^2} \quad (3.41)$$

的项. 把这些项合在一起, 得到完整六点相关子层依赖的递推

$$G_6^{(\ell+1)} = C_W^3 \left(1 + \frac{6}{n_\ell} + \frac{8}{n_\ell^2} \right) G_6^{(\ell)}, \quad (3.42)$$

其简单解为

$$\begin{aligned} G_6^{(\ell)} &= C_W^{3\ell} \left[\prod_{\ell'=1}^{\ell-1} \left(1 + \frac{6}{n_{\ell'}} + \frac{8}{n_{\ell'}^2} \right) \right] \left(G_2^{(0)} \right)^3 \\ &= \left[\prod_{\ell'=1}^{\ell-1} \left(1 + \frac{6}{n_{\ell'}} + \frac{8}{n_{\ell'}^2} \right) \right] \left(G_2^{(\ell)} \right)^3. \end{aligned} \quad (3.43)$$

这里使用了初始条件 (3.34) $G_6^{(0)} = \left(G_2^{(0)} \right)^3$, 最后一行还代入了单个输入方差的解 (3.15).

类似地, 可以把任意 $2m$ 点相关子分解为

$$\mathbb{E} \left[z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} \cdots z_{i_{2m-1}}^{(\ell)} z_{i_{2m}}^{(\ell)} \right] = \left(\sum_{\text{所有配对}} \delta_{i_{k_1} i_{k_2}} \cdots \delta_{i_{k_{2m-1}} i_{k_{2m}}} \right) G_{2m}^{(\ell)}, \quad (3.44)$$

再用类似操作说明层依赖 $G_{2m}^{(\ell)}$ 满足递推

$$G_{2m}^{(\ell+1)} = c_{2m}(n_\ell) C_W^m G_{2m}^{(\ell)}, \quad (3.45)$$

其中组合因子 $c_{2m}(n)$ 为

$$c_{2m}(n) = \left(1 + \frac{2}{n} \right) \left(1 + \frac{4}{n} \right) \cdots \left(1 + \frac{2m-2}{n} \right) = \frac{\left(\frac{n}{2} - 1 + m \right)!}{\left(\frac{n}{2} - 1 \right)!} \left(\frac{2}{n} \right)^m. \quad (3.46)$$

这里只为完整起见给出该因子的显式形式. 如果坚持检验它, 请注意, 它会对 $2m = 2, 4, 6$ 复现正确的组合因子; 不过, 我们强烈建议不要对其他任何特定 m 值逐项写出全部项. 总体而言, 这个递推仍只是一串简单乘法, 其简单解为

$$G_{2m}^{(\ell)} = \left[\prod_{\ell'=1}^{\ell-1} c_{2m}(n_{\ell'}) \right] \left(G_2^{(\ell)} \right)^m. \quad (3.47)$$

数学已经够多了, 该讨论物理了.³⁵

³⁵如果你确实还想看更多数学, 可参阅 [26]: 其中给出了这些 $2m$ 点相关子的另一种推导, 以及分布 $p(z^{(\ell)}|x)$ 的非微扰表达式.

物理：微扰论失效与混沌涌现

对公式 (3.47) 取不同极限，看看会发生什么. 为简单起见，令所有隐藏层宽度相等，即 $n_1 = n_2 = \dots = n_{L-1} \equiv n$ ，并且只考察输出分布 $p(z^{(L)}|x)$.

- 一方面，若保持深度 L 固定，并令网络宽度趋于无穷 $n \rightarrow \infty$ ，则所有组合因子 (3.46) 都趋于一：

$$\lim_{n \rightarrow \infty} c_{2m}(n) = 1. \quad (3.48)$$

在这一无限宽极限中，所有相关子 (3.47) 都取其高斯值

$$G_{2m}^{(L)} = \left(G_2^{(L)}\right)^m, \quad (3.49)$$

而输出分布 $p(z^{(L)}|x)$ 恰为高斯分布. 更一般地，即使有多个输入，输出分布 $p(z^{(L)}|\mathcal{D})$ 仍为高斯分布，其协方差为 $G_{\alpha_1\alpha_2}^{(L)} = C_W^L \left(\frac{1}{n_0} \sum_{i=1}^{n_0} x_{i;\alpha_1} x_{i;\alpha_2}\right)$. 这个分布等价于权重方差初始化为 C_W^L 的单层网络的分布，由此可见，这种网络归根结底并不真正深.

- 另一方面，若保持宽度 n 固定，并令深度趋于无穷 $L \rightarrow \infty$ ，那么所有组合因子都固定且大于一，即 $c_{2m} > 1$. 这意味着 $2m > 2$ 的高阶相关子全都会按下式指数爆炸：

$$G_{2m}^{(L)} = \left[c_{2m}(n)\right]^{L-1} \left(G_2^{(L)}\right)^m. \quad (3.50)$$

注意，即使把 $C_W = 1$ ，将网络调到临界性，从而使二点相关子固定为 $G_2^{(\ell)} = G_2^{(0)}$ ，这种行为仍然存在. 这明确展示了：如果网络深度变得过大，上一节的大宽度分析会如何失效. 此外，由这些相关子蕴含的分布至少可以说是极端非高斯的；实际中，这些网络的输出会随实现不同而发生混沌涨落. 这种网络完全无法使用.

- 显然，这两个极限不可交换，即

$$\lim_{n \rightarrow \infty} \lim_{L \rightarrow \infty} G_{2m}^{(L)} \neq \lim_{L \rightarrow \infty} \lim_{n \rightarrow \infty} G_{2m}^{(L)}. \quad (3.51)$$

不过，可以同时令宽度和深度趋于无穷 $n, L \rightarrow \infty$ ，并保持二者之比固定，以构造一个插值解：

$$r \equiv \frac{L}{n}. \quad (3.52)$$

注意，组合因子可展开为

$$c_{2m}(n) = 1 + \frac{1}{n} \left(\sum_{s=1}^{m-1} 2s \right) + O\left(\frac{1}{n^2}\right) = 1 + \frac{m(m-1)}{n} + O\left(\frac{1}{n^2}\right), \quad (3.53)$$

再利用著名的指数公式

$$\lim_{L \rightarrow \infty} \left[1 + \frac{a}{L} + O\left(\frac{1}{L^2}\right) \right]^L = e^a, \quad (3.54)$$

便可在给定 m 和固定深宽比 r 下，为任意相关子构造极限值：

$$G_{2m}^{(L)} \rightarrow e^{m(m-1)r} \left(G_2^{(L)}\right)^m. \quad (3.55)$$

该解在两个极端极限之间插值：令 $r \rightarrow 0$ ，恢复高斯极限 (3.49)；令 $r \rightarrow \infty$ ，则恢复展示临界性失效的混沌极限 (3.50).³⁶

在 $G_2^{(L)} = G_2^{(0)}$ 的临界性处，进一步考察最后的插值公式 (3.55). 此时，控制连通四点相关子 (3.29) 的有限宽差值 (3.28) 变为

$$\begin{aligned} G_4^{(L)} - \left(G_2^{(L)}\right)^2 &= (e^{2r} - 1) \left(G_2^{(0)}\right)^2 \\ &= 2r \left(G_2^{(0)}\right)^2 + O(r^2). \end{aligned} \quad (3.56)$$

这再现了四次耦合随深宽比的跑动 (3.28). 类似地，控制连通六点相关子 (1.61) 层依赖的相应量为

$$\begin{aligned} G_6^{(L)} - 3G_2^{(L)}G_4^{(L)} + 2\left(G_2^{(L)}\right)^3 &= (e^{6r} - 3e^{2r} + 2) \left(G_2^{(0)}\right)^3 \\ &= 12r^2 \left(G_2^{(0)}\right)^3 + O(r^3), \end{aligned} \quad (3.57)$$

它按深宽比的平方标度. 因此，对于深宽比 r 足够小的大型网络，连通六点相关子受到的抑制甚至强于连通四点相关子. 这与 §1.3 中的讨论一致：神经网络遵循近高斯统计，连通相关子具有层级结构. 特别地，这里可以看到，各相关子的标度由同一个小参数 r 控制，而高阶连通相关子受到该参数更高次幂的抑制. 这意味着当 r 很小时，可以一致地截断分布，只计算到 r 的某个固定阶.

³⁶ 这一双标度极限相当于忽略标度如 $\frac{L}{n^2}$ 、 $\frac{L^3}{n^5}$ 、 $\frac{L^{120}}{n^{157}}$ 等的项. 当深度与宽度都很大，即 $n, L \rightarrow \infty$ ，但二者之比 r 固定时，这些项全都是次领头的.

此外，当我们考察的不是某个给定 $2m$ 的特定相关子，而是全部相关子的集合时，使用这一插值解还存在一个非常微妙的理论问题. 也就是说，对于任意有限的 n, L ——不论它们多大——总有一些高阶相关子会因 $m(m-1)$ 因子过大，而使指数近似 (3.55) 失效. 换言之，这个插值解是在假定 m 固定的条件下构造的；若 m 足够大，它就可能失效.

第 4 章

预激活量的表征群流

“在一个大 N 矩阵中，你可以藏下很多东西。”——Steve Shenker——*John McGreevy* [27].

上一章末尾，我们计算了深度线性网络初始化时预激活量的统计，并看到它们如何随网络深度发生跑动。对这个玩具模型，借助少量 Wick 缩并与网络架构的递推结构，我们得以完整理解网络超参数——初始化方案、宽度与深度——如何影响预激活量相关子。这一练习特别凸显了临界初始化超参数与足够小的深宽比的重要性；只有满足这些条件，网络输出才能在理论和实践中都表现良好。为把这些认识推广到深度线性网络之外，我们需要为采用任意激活函数的网络发展深度学习有效理论。

尽管有效理论的最终目标是解释某个特定神经网络如何从给定数据集学习，§4 与 §5 的近期目标，却是理解初始化时神经网络系统如何依赖数据。在 §10、§11 与 §∞ 中，我们将发现这两个目标紧密相连：审慎研究系统，可以系统评估训练后网络的典型行为，以及任一特定网络可能如何涨落并偏离典型性。因此，我们从研究采用高斯初始化偏置与权重的神经网络预激活量统计开始。总而言之，本章为分析初始化网络系统而建立的形式体系，将从原理上理解深度学习的关键。

正如导论 §0 所强调的，我们始终专注于描述真实的有限宽网络，因为理想化无限宽网络会丢失许多现象。无限宽极限中消失的一个突出效应，是更深层预激活量分布不断增强的非高斯性。这种非高斯性使有限宽网络的行为丰富得多，也更难分析。为驾驭这些复杂性，我们需要借用理论物理的一些工具。物理学家一向善于在自由度数目很大的极限下，为复杂系统寻找简单描述，同时牢记真正目标是建模真实系统。在我们的语境中，这提示网络很宽、但并非无限宽的区域可能具有可处理性并发生简化。为精确表达这一点，本章引入大 n 展开，也就是 $1/n$ 展开；当隐藏层宽度 n 在参数意义下很大时，用它进行微扰展开。借助这一工具，我们将能以任意精度系统研究有限神经网络的预激活量分布。³⁷

³⁷早在 1996 年，Neal 就在奠基性工作 [28] 中引入了无限宽极限，重点考察单隐藏层网络。很久以后，这一路线由 [29, 30] 延续，把无限宽极限推广到更深网络；随后 Yaida 又在 [31] 中把它进一步推广到有限宽网络。本章很大一部分内容旨在复现 [31] 最先导出的递推。

不过，我们的视角不同于这些既有工作。特别地，我们的主要动机是计算初始化时的预激活量分布，着眼于最终理解基于梯度的训练（§10、§11、§∞），而不是为贝叶斯推断提供起点。（我们将在 §6 给出自己对深度学习贝叶斯学习的看法。）此外，与 [31] 不同，这里的结果先聚焦于作用量中的耦合，而不是

与深度线性网络的处理相同，我们将递推地推进：沿着 MLP 迭代前向传播方程对输入的变换，研究预激活量分布如何逐层改变。首先在 §4.1 中，对第一组权重和偏置积分，计算第一层的预激活量分布。这一过程恢复一个著名结果：第一层预激活量的分布是高斯分布。由于该计算对本章其余部分至关重要，我们会给出两种不同推导：用 Wick 缩并进行组合推导，以及用 Hubbard-Stratonovich 变换进行代数推导。

接下来，在 §4.2 中考察第二层预激活量分布，并看到非高斯性如何在四点及高阶连通相关子中涌现。当网络很宽时，这些相关子的大小受到抑制，并在严格无限宽极限中消失。宽网络中的这种抑制，使我们能够利用 §1 所研究的连通相关子与作用量耦合之间的对应关系，写出描述预激活量分布的作用量。特别地，大 n 展开允许我们从描述无限宽极限中高斯分布的二次作用量出发，再围绕它按宽度倒数 $1/n$ 作微扰级数展开，达到任意所需精度。鉴于这一结果的重要性，我们再次给出两种推导：一种基于 Wick 缩并，另一种基于随机度量的展开。

最后，在 §4.3 中分析任意深度处的预激活量分布。此时，只需重新利用前几节的计算，就能看到预激活量分布如何从第 ℓ 层递推地变换到第 $(\ell+1)$ 层。特别地，保留领头有限宽 $1/n$ 修正后，将得到二点与四点相关子的递推方程，它们编码这些可观测量如何随深度增加而演化。我们会看到，第 $(\ell+1)$ 层预激活量分布既包含从第 ℓ 层继承的近高斯部分，也包含从第 ℓ 层到第 $(\ell+1)$ 层的转移中新生成的近高斯性。下一章 §5 将通过显式求解这些递推并分析其解，详细说明近高斯性如何随深度累积；这会把临界性与深宽比涌现的概念推广到采用一般激活函数的网络。

在用一小节澄清边缘化的若干含义 (§4.4)，并用一节讨论次领头修正 (§4.5) 之后，我们在 §4.6 中退后一步，把本书的形式体系与理论物理中的重整化群作类比。重整化群是一种理解复杂相互作用系统的强大递推方法；当测量尺度从微观变为宏观时，它捕捉系统组分之间的有效相互作用如何改变。具体而言，重整化把系统的微观自由度边缘化，得到长距离上的有效粗粒化描述。这类似于我们递推地边缘化先前各层的预激活量，以得到当前层表征的有效描述；在这里，它刻画神经元之间的相互作用如何随深度改变。两种情形中，分布的流都源于细粒度信息的边缘化。鉴于这种完整的对应关系，我们把自己的流称为表征群 (RG) 流。

如果这听起来像一种流行的启发式解释——深度神经网络把输入层的细粒度信息，逐步变换为特征层的较粗信息，最终成为输出层的完全粗粒化表征——那是因为我们的形式体系使这种表征粗粒化图景变得具体。³⁸ 我们的形式体系还允许我们随着层数增加追踪预激活量分布的变化，从而直接探测深度学习中深度的作用。因此，它是深度学习有效理论的起点；我们将在全书余下部分继续发展这一理论。

4.1 第一层：经典高斯

给定数据集

$$\mathcal{D} = \{x_{i;\alpha}\}_{i=1,\dots,n_0; \alpha=1,\dots,N_{\mathcal{D}}} \quad (4.1)$$

直接聚焦于分布的相关子。这种方法更直观，也更容易推广。

³⁸ 关于重整化与深度学习之间的联系，已经有过许多正式和非正式评论，但这种关系此前从未被精确建立。

其中包含 N_D 个 n_0 维向量输入，第一层预激活量为

$$z_{i;\alpha}^{(1)} \equiv z_i^{(1)}(x_\alpha) = b_i^{(1)} + \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha}, \quad \text{其中 } i = 1, \dots, n_1. \quad (4.2)$$

初始化时，偏置 $b^{(1)}$ 与权重 $W^{(1)}$ 相互独立，并分别服从零均值高斯分布，其方差为

$$\mathbb{E} [b_i^{(1)} b_j^{(1)}] = \delta_{ij} C_b^{(1)}, \quad (4.3)$$

$$\mathbb{E} [W_{i_1 j_1}^{(1)} W_{i_2 j_2}^{(1)}] = \delta_{i_1 i_2} \delta_{j_1 j_2} \frac{C_W^{(1)}}{n_0}. \quad (4.4)$$

第一层预激活量 $z^{(1)} = z_{i;\alpha}^{(1)}$ 构成一个 $(n_1 N_D)$ 维向量；我们关心它在初始化时的分布

$$p(z^{(1)} | \mathcal{D}) = p(z^{(1)}(x_1), \dots, z^{(1)}(x_{N_D})). \quad (4.5)$$

注意，该分布以输入数据为条件，这反映了预激活量是输入的函数这一事实。

现在计算初始化时第一层预激活量的分布。由于这一结果非常重要，我们将给出两种推导：一种是组合推导，另一种是代数推导。

Wick 路径：通过相关子的组合推导

第一种推导直接应用 Wick 缩并，计算第一层分布 (4.5) 的相关子。从一点相关子开始，只需代入第一层预激活量的定义 (4.2)，得到

$$\mathbb{E} [z_{i;\alpha}^{(1)}] = \mathbb{E} \left[b_i^{(1)} + \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha_1} \right] = 0, \quad (4.6)$$

因为 $\mathbb{E} [b_i^{(1)}] = \mathbb{E} [W_{ij}^{(1)}] = 0$ 。事实上，很容易看出 $p(z^{(1)} | \mathcal{D})$ 的所有奇数点相关子都为零：在 Wick 缩并下，总会剩下奇数个无法配对的偏置 $b^{(1)}$ 或权重 $W^{(1)}$ 。

接着考察二点相关子。再次代入定义 (4.2)，可见

$$\begin{aligned} \mathbb{E} [z_{i_1;\alpha_1}^{(1)} z_{i_2;\alpha_2}^{(1)}] &= \mathbb{E} \left[\left(b_{i_1}^{(1)} + \sum_{j_1=1}^{n_0} W_{i_1 j_1}^{(1)} x_{j_1;\alpha_1} \right) \left(b_{i_2}^{(1)} + \sum_{j_2=1}^{n_0} W_{i_2 j_2}^{(1)} x_{j_2;\alpha_2} \right) \right] \\ &= \delta_{i_1 i_2} \left(C_b^{(1)} + C_W^{(1)} \frac{1}{n_0} \sum_{j=1}^{n_0} x_{j;\alpha_1} x_{j;\alpha_2} \right) = \delta_{i_1 i_2} G_{\alpha_1 \alpha_2}^{(1)}. \end{aligned} \quad (4.7)$$

从第一行到第二行，我们利用 (4.3) 与 (4.4) 对偏置和权重作 Wick 缩并。同时引入第一层度量

$$G_{\alpha_1 \alpha_2}^{(1)} \equiv C_b^{(1)} + C_W^{(1)} \frac{1}{n_0} \sum_{j=1}^{n_0} x_{j;\alpha_1} x_{j;\alpha_2}, \quad (4.8)$$

它是两个样本的函数 $G_{\alpha_1 \alpha_2}^{(1)} = G^{(1)}(x_{\alpha_1}, x_{\alpha_2})$ ，表示第一层中不同样本之间预激活量的二点相关。

高阶相关子也能用类似方法得到. 例如, 把定义 (4.2) 代入四次, 并对偏置和权重作 Wick 缩并, 便得到完整四点相关子

$$\begin{aligned}
& \mathbb{E} \left[z_{i_1; \alpha_1}^{(1)} z_{i_2; \alpha_2}^{(1)} z_{i_3; \alpha_3}^{(1)} z_{i_4; \alpha_4}^{(1)} \right] \\
&= \delta_{i_1 i_2} \delta_{i_3 i_4} G_{\alpha_1 \alpha_2}^{(1)} G_{\alpha_3 \alpha_4}^{(1)} + \delta_{i_1 i_3} \delta_{i_2 i_4} G_{\alpha_1 \alpha_3}^{(1)} G_{\alpha_2 \alpha_4}^{(1)} + \delta_{i_1 i_4} \delta_{i_2 i_3} G_{\alpha_1 \alpha_4}^{(1)} G_{\alpha_2 \alpha_3}^{(1)} \\
&= \mathbb{E} \left[z_{i_1; \alpha_1}^{(1)} z_{i_2; \alpha_2}^{(1)} \right] \mathbb{E} \left[z_{i_3; \alpha_3}^{(1)} z_{i_4; \alpha_4}^{(1)} \right] + \mathbb{E} \left[z_{i_1; \alpha_1}^{(1)} z_{i_3; \alpha_3}^{(1)} \right] \mathbb{E} \left[z_{i_2; \alpha_2}^{(1)} z_{i_4; \alpha_4}^{(1)} \right] \\
&\quad + \mathbb{E} \left[z_{i_1; \alpha_1}^{(1)} z_{i_4; \alpha_4}^{(1)} \right] \mathbb{E} \left[z_{i_2; \alpha_2}^{(1)} z_{i_3; \alpha_3}^{(1)} \right].
\end{aligned} \tag{4.9}$$

注意, 最终结果与用方差 (4.7) 对 $z^{(1)}$ 作 Wick 缩并完全相同. 回顾 §1, 这可以紧凑地表述为连通四点相关子为零:

$$\mathbb{E} \left[z_{i_1; \alpha_1}^{(1)} z_{i_2; \alpha_2}^{(1)} z_{i_3; \alpha_3}^{(1)} z_{i_4; \alpha_4}^{(1)} \right] \Big|_{\text{连通}} = 0. \tag{4.10}$$

类似的 Wick 组合分析表明, 所有完整高阶相关子都可以仅用方差 (4.7) 对 $z^{(1)}$ 作 Wick 缩并得到, 因此所有高阶连通相关子均为零. 这意味着全部相关子都能由零均值、方差为 (4.7) 的高斯分布生成.

于是, 要写下第一层作用量, 只需取该方差的逆, 即矩阵 $\delta_{i_1 i_2} G_{(1)}^{\alpha_1 \alpha_2}$, 它满足

$$\sum_{j=1}^{n_1} \sum_{\beta \in \mathcal{D}} \left(\delta_{i_1 j} G_{(1)}^{\alpha_1 \beta} \right) \left(\delta_{j i_2} G_{\beta \alpha_2}^{(1)} \right) = \delta_{i_1 i_2} \delta_{\alpha_1 \alpha_2}^{\alpha_1}, \tag{4.11}$$

第一层度量 $G_{\alpha_1 \alpha_2}^{(1)}$ 的逆记作 $G_{(1)}^{\alpha_1 \alpha_2}$, 定义为

$$\sum_{\beta \in \mathcal{D}} G_{(1)}^{\alpha_1 \beta} G_{\beta \alpha_2}^{(1)} = \delta_{\alpha_1 \alpha_2}^{\alpha_1}. \tag{4.12}$$

与 §1 相同, 我们沿用广义相对论的约定, 省略逆度量上标中的 “-1”; 通过样本指标是降低还是升高, 来区分度量 $G_{\alpha_1 \alpha_2}^{(1)}$ 与逆度量 $G_{(1)}^{\alpha_1 \alpha_2}$. 使用这一记号, 第一层预激活量的高斯分布可表示为

$$p(z^{(1)} | \mathcal{D}) = \frac{1}{Z} e^{-S(z^{(1)})}, \tag{4.13}$$

其中二次作用量为

$$S(z^{(1)}) = \frac{1}{2} \sum_{i=1}^{n_1} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(1)}^{\alpha_1 \alpha_2} z_{i; \alpha_1}^{(1)} z_{i; \alpha_2}^{(1)}, \tag{4.14}$$

而配分函数为

$$Z = \int \left[\prod_{i, \alpha} dz_{i; \alpha}^{(1)} \right] e^{-S(z^{(1)})} = |2\pi G^{(1)}|^{\frac{n_1}{2}}, \tag{4.15}$$

这里 $|2\pi G^{(1)}|$ 是 $N_{\mathcal{D}} \times N_{\mathcal{D}}$ 矩阵 $2\pi G_{\alpha_1 \alpha_2}^{(1)}$ 的行列式; 今后只要写出涉及度量的行列式, 它始终指度量的行列式, 而不是逆度量的行列式.³⁹

³⁹注意, 与 (1.66) 中引入的一般二次作用量相比, 那里随机变量 z_{μ} 是带一般指标 μ 的向量; 而在 (4.14) 中, 我们把一般指标拆成一对指标 $\mu \rightarrow (i, \alpha)$, 因此第一层预激活量 $z_{i; \alpha}^{(1)}$ 是一个张量, 带神经元指标 i 与样本指标 α .

Hubbard–Stratonovich 路径：通过作用量的代数推导

与其先计算相关子，再反推出生成这些相关子的分布，我们也可以直接处理分布。从上一章得到的预激活量分布形式表达式 (2.33) 出发⁴⁰

$$p(z|\mathcal{D}) = \int \left[\prod_i db_i p(b_i) \right] \left[\prod_{i,j} dW_{ij} p(W_{ij}) \right] \prod_{i,\alpha} \delta \left(z_{i;\alpha} - b_i - \sum_j W_{ij} x_{j;\alpha} \right), \quad (4.16)$$

这里暂时省略了层上标“(1)”，以免分散注意力。此时可以尝试利用 Dirac delta 函数施加的约束，消去一部分模型参数积分；但模型参数积分数目与 delta 函数约束数目不同，很容易混淆。

为澄清这一问题，采用 **Hubbard–Stratonovich 变换**这一来自理论物理的巧妙技巧。具体而言，对每个约束使用 Dirac delta 函数 (2.32) 的下列积分表示

$$\delta(z - a) = \int \frac{d\Lambda}{2\pi} e^{i\Lambda(z-a)}, \quad (4.17)$$

再代入参数高斯分布的显式表达式，得到

$$p(z|\mathcal{D}) = \int \left[\prod_i \frac{db_i}{\sqrt{2\pi C_b}} \right] \left[\prod_{i,j} \frac{dW_{ij}}{\sqrt{2\pi C_W/n_0}} \right] \left[\prod_{i,\alpha} \frac{d\Lambda_i^\alpha}{2\pi} \right], \quad (4.18)$$

$$\times \exp \left[-\sum_i \frac{b_i^2}{2C_b} - n_0 \sum_{i,j} \frac{W_{ij}^2}{2C_W} + i \sum_{i,\alpha} \Lambda_i^\alpha \left(z_{i;\alpha} - b_i - \sum_j W_{ij} x_{j;\alpha} \right) \right].$$

对指数中的偏置 b 与权重 W 分别配方，可见作用量关于模型参数是二次的：

$$-\sum_i \frac{b_i^2}{2C_b} - n_0 \sum_{i,j} \frac{W_{ij}^2}{2C_W} + i \sum_{i,\alpha} \Lambda_i^\alpha \left(z_{i;\alpha} - b_i - \sum_j W_{ij} x_{j;\alpha} \right) \quad (4.19)$$

$$= -\frac{1}{2C_b} \sum_i \left(b_i + iC_b \sum_\alpha \Lambda_i^\alpha \right)^2 - \frac{C_b}{2} \sum_i \left(\sum_\alpha \Lambda_i^\alpha \right)^2$$

$$- \frac{n_0}{2C_W} \sum_{i,j} \left(W_{ij} + i \frac{C_W}{n_0} \sum_\alpha \Lambda_i^\alpha x_{j;\alpha} \right)^2 - \frac{C_W}{2n_0} \sum_{i,j} \left(\sum_\alpha \Lambda_i^\alpha x_{j;\alpha} \right)^2 + i \sum_{i,\alpha} \Lambda_i^\alpha z_{i;\alpha}.$$

于是可以把偏置与权重积分掉，得到第一层分布 $p(z)$ 的积分表示

$$\int \left[\prod_{i,\alpha} \frac{d\Lambda_i^\alpha}{2\pi} \right] \exp \left[-\frac{1}{2} \sum_{i,\alpha_1,\alpha_2} \Lambda_i^{\alpha_1} \Lambda_i^{\alpha_2} \left(C_b + C_W \sum_j \frac{x_{j;\alpha_1} x_{j;\alpha_2}}{n_0} \right) + i \sum_{i,\alpha} \Lambda_i^\alpha z_{i;\alpha} \right]. \quad (4.20)$$

本质上，到这里我们已经用辅助 Hubbard–Stratonovich 变量 Λ_i^α 取代了 delta 函数约束与模型参数；这些辅助变量具有二次作用量，并与预激活量 $z_{i;\alpha}$ 发生简单线性相互作用。

⁴⁰对于 MLP 以外的架构，Dirac delta 函数内部的表达式会不同；不过，只要参数从简单分布中抽样，我们预期下面的大部分论证仍然成立。

注意，Hubbard–Stratonovich 变量 Λ_i^α 的逆方差，恰好就是 Wick 缩并推导中引入的第一层度量 (4.8)：

$$C_b^{(1)} + C_W^{(1)} \sum_j \frac{x_{j;\alpha_1} x_{j;\alpha_2}}{n_0} = G_{\alpha_1 \alpha_2}^{(1)}, \quad (4.21)$$

现在尘埃已经落定，可以恢复层上标“(1)”。再次配方，指数的宗量变成

$$-\frac{1}{2} \sum_{i, \alpha_1, \alpha_2} \left[G_{\alpha_1 \alpha_2}^{(1)} \left(\Lambda_i^{\alpha_1} - i \sum_{\beta_1} G_{(1)}^{\alpha_1 \beta_1} z_{i;\beta_1}^{(1)} \right) \left(\Lambda_i^{\alpha_2} - i \sum_{\beta_2} G_{(1)}^{\alpha_2 \beta_2} z_{i;\beta_2}^{(1)} \right) + G_{(1)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(1)} z_{i;\alpha_2}^{(1)} \right], \quad (4.22)$$

最终便可把 Hubbard–Stratonovich 变量 Λ_i^α 积分掉，恢复前面的结果

$$p(z^{(1)} | \mathcal{D}) = \frac{1}{|2\pi G^{(1)}|^{\frac{n_1}{2}}} \exp \left(-\frac{1}{2} \sum_{i=1}^{n_1} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(1)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(1)} z_{i;\alpha_2}^{(1)} \right). \quad (4.23)$$

与前面一样， $|2\pi G^{(1)}|$ 表示矩阵 $2\pi G_{\alpha_1 \alpha_2}^{(1)}$ 的行列式。第一层分布是高斯分布，各神经元彼此独立；不同样本的预激活量之间的相关完全编码在度量 $G_{\alpha_1 \alpha_2}^{(1)}$ 中。

高斯作用量的应用

现在，我们已经用两种不同方法得到第一层预激活量分布的作用量表示；接下来熟悉如何用它计算。首先计算 §4.2 中将会用到的一些量：同一神经元上两个激活的期望 $\mathbb{E} \left[\sigma(z_{i_1; \alpha_1}^{(1)}) \sigma(z_{i_1; \alpha_2}^{(1)}) \right]$ ，以及四个激活的期望 $\mathbb{E} \left[\sigma(z_{i_1; \alpha_1}^{(1)}) \sigma(z_{i_1; \alpha_2}^{(1)}) \sigma(z_{i_2; \alpha_3}^{(1)}) \sigma(z_{i_2; \alpha_4}^{(1)}) \right]$ ；后者既可让四个激活都位于同一神经元 $i_1 = i_2$ ，也可让两对激活分别位于两个不同神经元 $i_1 \neq i_2$ 。

先从激活的二点相关子开始。使用期望的定义，并代入分布的作用量表示 (4.23)，得到

$$\begin{aligned} & \mathbb{E} \left[\sigma(z_{i_1; \alpha_1}^{(1)}) \sigma(z_{i_1; \alpha_2}^{(1)}) \right] \\ &= \int \left[\prod_{i=1}^{n_1} \frac{\prod_{\alpha \in \mathcal{D}} dz_{i;\alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{j=1}^{n_1} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{j;\beta_1} z_{j;\beta_2} \right) \sigma(z_{i_1; \alpha_1}) \sigma(z_{i_1; \alpha_2}) \\ &= \left\{ \prod_{i \neq i_1} \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_{i;\alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{i;\beta_1} z_{i;\beta_2} \right) \right\} \\ & \quad \times \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_{i_1; \alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{i_1; \beta_1} z_{i_1; \beta_2} \right) \sigma(z_{i_1; \alpha_1}) \sigma(z_{i_1; \alpha_2}) \\ &= \{1\} \times \left[\int \frac{\prod_{\alpha \in \mathcal{D}} dz_\alpha}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{\beta_1} z_{\beta_2} \right) \sigma(z_{\alpha_1}) \sigma(z_{\alpha_2}) \\ &\equiv \langle \sigma(z_{\alpha_1}) \sigma(z_{\alpha_2}) \rangle_{G^{(1)}}. \end{aligned} \quad (4.24)$$

第二个等号利用 $e^{x+y} = e^x e^y$ ，表明概率分布按每个神经元因子化。从第二个等号到第三个等号，我们计算了 $i \neq i_1$ 各神经元的积分；这些积分都很平凡，同时把哑积分变量

$z_{i_1;\alpha}$ 重命名为 z_α . 最后一个等号重新引入记号 (1.68)

$$\langle F(z_{\alpha_1}, \dots, z_{\alpha_m}) \rangle_g \equiv \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_\alpha}{\sqrt{|2\pi g|}} \right] \exp\left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} g^{\beta_1 \beta_2} z_{\beta_1} z_{\beta_2}\right) F(z_{\alpha_1}, \dots, z_{\alpha_m}), \quad (4.25)$$

用来描述方差为 g 、任意函数为 $F(z_{\alpha_1}, \dots, z_{\alpha_m})$ 的高斯期望，其中变量只带样本指标. 本书其他部分会针对具体激活函数，在不同设定下显式计算这种高斯期望；但在本章，只要把计算约化为不含神经元指标的这种高斯期望，就视为计算完成.

再引入简化记号

$$\sigma_\alpha \equiv \sigma(z_\alpha), \quad (4.26)$$

上面的计算结果可简洁概括为

$$\mathbb{E} \left[\sigma \left(z_{i_1; \alpha_1}^{(1)} \right) \sigma \left(z_{i_1; \alpha_2}^{(1)} \right) \right] = \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}}. \quad (4.27)$$

很容易把它推广到两个以上激活的相关子. 例如，对于同一神经元 $i_1 = i_2$ 上的四个激活，完全相同的操作给出

$$\mathbb{E} \left[\sigma \left(z_{i_1; \alpha_1}^{(1)} \right) \sigma \left(z_{i_1; \alpha_2}^{(1)} \right) \sigma \left(z_{i_1; \alpha_3}^{(1)} \right) \sigma \left(z_{i_1; \alpha_4}^{(1)} \right) \right] = \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}}, \quad (4.28)$$

而对于分别位于两个不同神经元 $i_1 \neq i_2$ 上的两对激活，有

$$\begin{aligned} & \mathbb{E} \left[\sigma \left(z_{i_1; \alpha_1}^{(1)} \right) \sigma \left(z_{i_1; \alpha_2}^{(1)} \right) \sigma \left(z_{i_2; \alpha_3}^{(1)} \right) \sigma \left(z_{i_2; \alpha_4}^{(1)} \right) \right] \\ &= \left\{ \prod_{i \notin \{i_1, i_2\}} \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_{i;\alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{i;\beta_1} z_{i;\beta_2} \right) \right\} \\ & \times \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_{i_1;\alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{i_1;\beta_1} z_{i_1;\beta_2} \right) \sigma(z_{i_1; \alpha_1}) \sigma(z_{i_1; \alpha_2}) \\ & \times \int \left[\frac{\prod_{\alpha \in \mathcal{D}} dz_{i_2;\alpha}}{\sqrt{|2\pi G^{(1)}|}} \right] \exp \left(-\frac{1}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(1)}^{\beta_1 \beta_2} z_{i_2;\beta_1} z_{i_2;\beta_2} \right) \sigma(z_{i_2; \alpha_3}) \sigma(z_{i_2; \alpha_4}) \\ &= \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}}. \end{aligned} \quad (4.29)$$

这里显然每个神经元都因子化，并分别给出高斯积分. 这说明各神经元彼此独立，因而第一层中不同神经元之间没有相互作用. 在更深层中，预激活量分布是近高斯的，情况会稍微复杂一些.

4.2 第二层：非高斯性的诞生

本节转而计算 MLP 第二层预激活量的分布. 第二层预激活量定义为

$$z_{i;\alpha}^{(2)} \equiv z_i^{(2)}(x_\alpha) = b_i^{(2)} + \sum_{j=1}^{n_1} W_{ij}^{(2)} \sigma_{j;\alpha}^{(1)}, \quad \text{其中 } i = 1, \dots, n_2, \quad (4.30)$$

第一层激活记作

$$\sigma_{i;\alpha}^{(1)} \equiv \sigma\left(z_{i;\alpha}^{(1)}\right), \quad (4.31)$$

偏置 $b^{(2)}$ 与权重 $W^{(2)}$ 从高斯分布中抽样.

第一层与第二层预激活量的联合分布可因子化为

$$p\left(z^{(2)}, z^{(1)} \mid \mathcal{D}\right) = p\left(z^{(2)} \mid z^{(1)}\right) p\left(z^{(1)} \mid \mathcal{D}\right). \quad (4.32)$$

上一节 §4.1 已经计算了第一层边缘分布 $p\left(z^{(1)} \mid \mathcal{D}\right)$ ：它是高斯分布 (4.23)，方差由第一层度量 $G_{\alpha_1 \alpha_2}^{(1)}$ 给出. 至于条件分布，我们知道它可以表示为⁴¹

$$\begin{aligned} & p\left(z^{(2)} \mid z^{(1)}\right) \\ &= \int \left[\prod_i db_i^{(2)} p\left(b_i^{(2)}\right) \right] \left[\prod_{i,j} dW_{ij}^{(2)} p\left(W_{ij}^{(2)}\right) \right] \prod_{i,\alpha} \delta\left(z_{i;\alpha}^{(2)} - b_i^{(2)} - \sum_j W_{ij}^{(2)} \sigma_{j;\alpha}^{(1)}\right), \end{aligned} \quad (4.33)$$

它来自上一章预激活量在给定前一层激活条件下的形式表达式 (2.34). 随后，通过对第一层预激活量作**边缘化**，或者说把它们**积分掉**，可得到第二层预激活量的边缘分布：

$$p\left(z^{(2)} \mid \mathcal{D}\right) = \int \left[\prod_{i,\alpha} dz_{i;\alpha}^{(1)} \right] p\left(z^{(2)} \mid z^{(1)}\right) p\left(z^{(1)} \mid \mathcal{D}\right). \quad (4.34)$$

为计算这个边缘分布 $p\left(z^{(2)} \mid \mathcal{D}\right)$ ，我们先讨论如何处理条件分布 $p\left(z^{(2)} \mid z^{(1)}\right)$ ，再说明如何对服从高斯分布 (4.23) 的第一层预激活量 $z^{(1)}$ 积分.

第二层条件分布

条件分布 (4.33) 的计算方式，与计算给定输入条件下的第一层分布 (4.16) 完全相同；只需把层指标从 1 换成 2，并把网络输入换成第一层激活，即 $x_{j;\alpha} \rightarrow \sigma_{j;\alpha}^{(1)}$. 不妨翻回 (4.16) 完成这些替换，再回想答案 (4.23)；很容易看出，计算给出

$$p\left(z^{(2)} \mid z^{(1)}\right) = \frac{1}{\sqrt{|2\pi\hat{G}^{(2)}|^{n_2}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \hat{G}_{(2)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(2)} z_{i;\alpha_2}^{(2)}\right), \quad (4.35)$$

其中定义随机第二层度量

$$\hat{G}_{\alpha_1 \alpha_2}^{(2)} \equiv C_b^{(2)} + C_W^{(2)} \frac{1}{n_1} \sum_{j=1}^{n_1} \sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)}. \quad (4.36)$$

帽号强调它是随机变量：通过 $\sigma^{(1)} \equiv \sigma(z^{(1)})$ 依赖随机变量 $z^{(1)}$. 因此，第二层条件分布 (4.35) 是一个高斯分布，但它的方差本身也是随机变量. 特别地，随机第二层度量围

⁴¹同样，Dirac delta 函数中的表达式是多层感知机架构特有的，但这一形式体系很容易适配其他架构.

绕平均第二层度量涨落：

$$\begin{aligned} G_{\alpha_1\alpha_2}^{(2)} &\equiv \mathbb{E} \left[\widehat{G}_{\alpha_1\alpha_2}^{(2)} \right] = C_b^{(2)} + C_W^{(2)} \frac{1}{n_1} \sum_{j=1}^{n_1} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \right] \\ &= C_b^{(2)} + C_W^{(2)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}}. \end{aligned} \quad (4.37)$$

最后一步使用了结果 (4.27)，计算同一神经元上第一层激活的二点相关子。

围绕这个均值，把第二层度量的涨落定义为

$$\widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)} \equiv \widehat{G}_{\alpha_1\alpha_2}^{(2)} - G_{\alpha_1\alpha_2}^{(2)} = C_W^{(2)} \frac{1}{n_1} \sum_{j=1}^{n_1} \left(\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \right), \quad (4.38)$$

按构造，在第一层预激活量上取平均时，它的均值为零：

$$\mathbb{E} \left[\widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)} \right] = 0. \quad (4.39)$$

涨落的典型大小由其二点相关子给出。回顾同一神经元上两个和四个激活的高斯积分 (4.27) 与 (4.28)，以及不同神经元上的因子化性质 (4.29)，得到

$$\begin{aligned} &\mathbb{E} \left[\widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)} \widehat{\Delta G}_{\alpha_3\alpha_4}^{(2)} \right] \\ &= \left(\frac{C_W^{(2)}}{n_1} \right)^2 \sum_{j,k=1}^{n_1} \mathbb{E} \left[\left(\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \right] \right) \left(\sigma_{k;\alpha_3}^{(1)} \sigma_{k;\alpha_4}^{(1)} - \mathbb{E} \left[\sigma_{k;\alpha_3}^{(1)} \sigma_{k;\alpha_4}^{(1)} \right] \right) \right] \\ &= \left(\frac{C_W^{(2)}}{n_1} \right)^2 \sum_{j=1}^{n_1} \left\{ \mathbb{E} \left[\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \sigma_{j;\alpha_3}^{(1)} \sigma_{j;\alpha_4}^{(1)} \right] - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \right] \mathbb{E} \left[\sigma_{j;\alpha_3}^{(1)} \sigma_{j;\alpha_4}^{(1)} \right] \right\} \\ &= \frac{1}{n_1} \left(C_W^{(2)} \right)^2 \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \right], \\ &\equiv \frac{1}{n_1} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(2)}, \end{aligned} \quad (4.40)$$

最后引入第二层**四点顶点** $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(2)} = V(x_{\alpha_1}, x_{\alpha_2}; x_{\alpha_3}, x_{\alpha_4})$ 。它依赖四个输入数据点，并在样本指标交换 $\alpha_1 \leftrightarrow \alpha_2$ 、 $\alpha_3 \leftrightarrow \alpha_4$ 以及 $(\alpha_1, \alpha_2) \leftrightarrow (\alpha_3, \alpha_4)$ 下对称。稍后将在 (4.43) 中理解这一量的意义。

这里也首次显现出宽网络区域 $n_1 \gg 1$ 中的简化：四点顶点显然是一阶量，因此该区域中的度量涨落会受到抑制。本质上，随着第一层神经元数增加，由于中心极限定理，度量涨落会越来越高斯。在严格的无限 n_1 极限中，度量将发生自平均，也就是说涨落会消失。

现在已经了解度量涨落的分布，可以真正把第一层预激活量 $z^{(1)}$ 积分掉，得到第二层预激活量的边缘分布 $p(z^{(2)} | \mathcal{D})$ 。我们再次给出两种推导：一种直接蛮算，另一种更为巧妙。

Wick Wick Wick：组合推导

第二层预激活量的相关子，可以漂亮地写成刚刚算出的随机度量期望。为计算这些相关子，首先利用条件分布 $p(z^{(2)} | z^{(1)})$ 是高斯分布这一事实 (4.35)，对第二层预激活

量 $z^{(2)}$ 作 Wick 缩并，所得表达式涉及随机度量 $\widehat{G}_{\alpha_1\alpha_2}^{(2)}$ 的期望；随后代入上面得到的随机度量期望表达式。

据此，第二层预激活量的二点相关子为

$$\mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} \right] = \delta_{i_1 i_2} \mathbb{E} \left[\widehat{G}_{\alpha_1\alpha_2}^{(2)} \right] = \delta_{i_1 i_2} G_{\alpha_1\alpha_2}^{(2)} = \delta_{i_1 i_2} \left(C_b^{(2)} + C_W^{(2)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \right), \quad (4.41)$$

更明确地说，我们先用 (4.35) 完成唯一一种 Wick 缩并，再代入随机度量均值的表达式 (4.37)。

类似地，完整四点函数可计算为

$$\begin{aligned} & \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} z_{i_3;\alpha_3}^{(2)} z_{i_4;\alpha_4}^{(2)} \right] \\ &= \delta_{i_1 i_2} \delta_{i_3 i_4} \mathbb{E} \left[\widehat{G}_{\alpha_1\alpha_2}^{(2)} \widehat{G}_{\alpha_3\alpha_4}^{(2)} \right] + \delta_{i_1 i_3} \delta_{i_2 i_4} \mathbb{E} \left[\widehat{G}_{\alpha_1\alpha_3}^{(2)} \widehat{G}_{\alpha_2\alpha_4}^{(2)} \right] + \delta_{i_1 i_4} \delta_{i_2 i_3} \mathbb{E} \left[\widehat{G}_{\alpha_1\alpha_4}^{(2)} \widehat{G}_{\alpha_2\alpha_3}^{(2)} \right], \\ &= \delta_{i_1 i_2} \delta_{i_3 i_4} G_{\alpha_1\alpha_2}^{(2)} G_{\alpha_3\alpha_4}^{(2)} + \delta_{i_1 i_3} \delta_{i_2 i_4} G_{\alpha_1\alpha_3}^{(2)} G_{\alpha_2\alpha_4}^{(2)} + \delta_{i_1 i_4} \delta_{i_2 i_3} G_{\alpha_1\alpha_4}^{(2)} G_{\alpha_2\alpha_3}^{(2)} \\ &+ \frac{1}{n_1} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(2)} + \delta_{i_1 i_3} \delta_{i_2 i_4} V_{(\alpha_1\alpha_3)(\alpha_2\alpha_4)}^{(2)} + \delta_{i_1 i_4} \delta_{i_2 i_3} V_{(\alpha_1\alpha_4)(\alpha_2\alpha_3)}^{(2)} \right], \end{aligned} \quad (4.42)$$

第一行利用高斯分布 (4.35)，对四个第二层预激活量 $z^{(2)}$ 作了三种 Wick 缩并；第二行则回顾 (4.39) 与 (4.40)，计算随机度量 $\widehat{G}_{\alpha_1\alpha_2}^{(2)} = G_{\alpha_1\alpha_2}^{(2)} + \widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)}$ 在第一层预激活量 $z^{(1)}$ 上的期望。这意味着，减去第二层预激活量二点相关子的贡献之后，连通四点相关子——回顾 (1.54)——为

$$\begin{aligned} & \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} z_{i_3;\alpha_3}^{(2)} z_{i_4;\alpha_4}^{(2)} \right] \Big|_{\text{connected}} \\ &= \frac{1}{n_1} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(2)} + \delta_{i_1 i_3} \delta_{i_2 i_4} V_{(\alpha_1\alpha_3)(\alpha_2\alpha_4)}^{(2)} + \delta_{i_1 i_4} \delta_{i_2 i_3} V_{(\alpha_1\alpha_4)(\alpha_2\alpha_3)}^{(2)} \right]. \end{aligned} \quad (4.43)$$

这里可以看出，在 (4.40) 中引入四点顶点的真正重要性：它给出第二层连通四点相关子，并控制第二层预激活量分布的近高斯性。因此，在 $n_1 \gg 1$ 的宽网络区域，这个连通相关子受到抑制；这表明网络越宽，预激活量分布就越接近高斯分布。由此可见，第二层预激活量分布 $p(z^{(2)} | \mathcal{D})$ 一般是非高斯的，但在大 n_1 区域会显著简化：在严格的 $n_1 = \infty$ 极限中变成高斯分布，而四点顶点 $V_{(\alpha_1\alpha_3)(\alpha_2\alpha_4)}^{(2)}$ 则度量对高斯性的领先偏离。

为了完成组合推导，还需要找到能够生成相关子 (4.41) 与 (4.43) 的作用量。已知二次作用量无法生成具有非平凡连通四点相关子的非高斯分布，因此需要一种适合近高斯分布的不同作用量。从 §1.2 中单变量非高斯积分得到的直觉表明，也许可以在作用量中加入四次项，生成所需的相关性。

本着这个想法，先为一个 $(nN_{\mathcal{D}})$ 维随机变量 z 写出四次作用量

$$\begin{aligned} S[z] &= \frac{1}{2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} g^{\alpha_1\alpha_2} \sum_{i=1}^n z_{i;\alpha_1} z_{i;\alpha_2} \\ &- \frac{1}{8} \sum_{\alpha_1, \dots, \alpha_4 \in \mathcal{D}} v^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} \sum_{i_1, i_2=1}^n z_{i_1;\alpha_1} z_{i_1;\alpha_2} z_{i_2;\alpha_3} z_{i_2;\alpha_4}, \end{aligned} \quad (4.44)$$

其中耦合 g 与 v 尚未确定。我们将微扰处理四次耦合 v ；稍后把四次耦合 v 与受 $1/n_1$ 抑制的连通四点相关子联系起来，便可证明这一假设的合理性。注意，按构造，四次耦合

$v^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}$ 对样本指标具有与四点顶点 $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(2)}$ 相同的对称结构.⁴² 利用这个作用量, 可以把二点与四点相关子计算到 v 的一阶. 随后与这些量的表达式 (4.41) 和 (4.43) 匹配, 就能知道应当如何调节耦合 g 与 v , 以在宽网络区域重现正确的第二层预激活量统计.

在继续之前, 引入一些方便的记号. 在 (4.25) 中, 我们用 $\langle F(z_{\alpha_1}, \dots, z_{\alpha_m}) \rangle_g$ 表示任意函数 F 在方差为 g 的高斯分布下的平均, 其中预激活变量 z_α 只带样本指标. 此外, 在这里定义

$$\begin{aligned} & \langle\langle F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}) \rangle\rangle_g \\ & \equiv \int \left[\prod_{i=1}^n \frac{\prod_{\alpha \in \mathcal{D}} dz_{i;\alpha}}{\sqrt{|2\pi g|}} \right] \exp\left(-\frac{1}{2} \sum_{j=1}^n \sum_{\beta_1, \beta_2 \in \mathcal{D}} g^{\beta_1\beta_2} z_{j;\beta_1} z_{j;\beta_2}\right) F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}), \end{aligned} \quad (4.45)$$

其中现在也包括神经元指标. 在处理 (4.27) 与 (4.29) 时已经看到, 这种平均可按神经元因子化为 (4.25) 形式的积分.

有了这个记号, 任意函数 $F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m})$ 在四次作用量 (4.44) 所定义分布下的期望, 可以改写成高斯期望, 并按耦合 v 作微扰展开:

$$\begin{aligned} & \mathbb{E}[F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m})] \\ & = \frac{\int \left[\prod_{i,\alpha} dz_{i;\alpha} \right] e^{-S(z)} F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m})}{\int \left[\prod_{i,\alpha} dz_{i;\alpha} \right] e^{-S(z)}} \\ & = \frac{\langle\langle \exp\left\{\frac{1}{8} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1\beta_2)(\beta_3\beta_4)} \sum_{j_1, j_2=1}^n z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4}\right\} F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}) \rangle\rangle_g}{\langle\langle \exp\left\{\frac{1}{8} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1\beta_2)(\beta_3\beta_4)} \sum_{j_1, j_2=1}^n z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4}\right\} \rangle\rangle_g} \\ & = \langle\langle F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}) \rangle\rangle_g \\ & \quad + \frac{1}{8} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1\beta_2)(\beta_3\beta_4)} \sum_{j_1, j_2=1}^n \left[\langle\langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}) \rangle\rangle_g \right. \\ & \quad \left. - \langle\langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} \rangle\rangle_g \langle\langle F(z_{i_1;\alpha_1}, \dots, z_{i_m;\alpha_m}) \rangle\rangle_g \right], \\ & \quad + O(v^2), \end{aligned} \quad (4.46)$$

第一行使用期望的定义; 第二行用刚引入的记号 (4.45) 改写分子和分母; 第三行则在分子与分母中都按耦合 v 展开指数函数. 简言之, 这个结果告诉我们, 如何用领先高斯期望与微扰修正, 微扰地表示四次作用量 (4.44) 所定义完整分布下的期望; 而这些微扰贡献仍然只涉及高斯期望, 因此容易计算.

接下来考虑 F 的几个具体选择. 从二点相关子开始, 得到

$$\begin{aligned} & \mathbb{E}[z_{i_1;\alpha_1} z_{i_2;\alpha_2}] \\ & = \delta_{i_1 i_2} \left[g_{\alpha_1 \alpha_2} + \frac{1}{2} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1\beta_2)(\beta_3\beta_4)} (n g_{\alpha_1 \beta_1} g_{\alpha_2 \beta_2} g_{\beta_3 \beta_4} + 2 g_{\alpha_1 \beta_1} g_{\alpha_2 \beta_3} g_{\beta_2 \beta_4}) \right] + O(v^2). \end{aligned} \quad (4.47)$$

⁴²式 (4.44) 中惯用的因子 $1/8$ 正是为了计入这一对称性.

这里方差 $g_{\alpha_1\alpha_2}$ 是二次耦合的逆, 满足 $\sum_{\beta} g_{\alpha_1\beta} g^{\beta\alpha_2} = \delta_{\alpha_1}^{\alpha_2}$. 类似地, 连通四点相关子为

$$\begin{aligned}
& \mathbb{E} [z_{i_1;\alpha_1} z_{i_2;\alpha_2} z_{i_3;\alpha_3} z_{i_4;\alpha_4}] \Big|_{\text{connected}} \\
& \equiv \mathbb{E} [z_{i_1;\alpha_1} z_{i_2;\alpha_2} z_{i_3;\alpha_3} z_{i_4;\alpha_4}] - \mathbb{E} [z_{i_1;\alpha_1} z_{i_2;\alpha_2}] \mathbb{E} [z_{i_3;\alpha_3} z_{i_4;\alpha_4}] \\
& \quad - \mathbb{E} [z_{i_1;\alpha_1} z_{i_3;\alpha_3}] \mathbb{E} [z_{i_2;\alpha_2} z_{i_4;\alpha_4}] - \mathbb{E} [z_{i_1;\alpha_1} z_{i_4;\alpha_4}] \mathbb{E} [z_{i_2;\alpha_2} z_{i_3;\alpha_3}] \\
& = \delta_{i_1 i_2} \delta_{i_3 i_4} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_2)(\beta_3 \beta_4)} g_{\alpha_1 \beta_1} g_{\alpha_2 \beta_2} g_{\alpha_3 \beta_3} g_{\alpha_4 \beta_4} \\
& \quad + \delta_{i_1 i_3} \delta_{i_2 i_4} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_3)(\beta_2 \beta_4)} g_{\alpha_1 \beta_1} g_{\alpha_3 \beta_3} g_{\alpha_2 \beta_2} g_{\alpha_4 \beta_4} \\
& \quad + \delta_{i_1 i_4} \delta_{i_2 i_3} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_4)(\beta_2 \beta_3)} g_{\alpha_1 \beta_1} g_{\alpha_4 \beta_4} g_{\alpha_2 \beta_2} g_{\alpha_3 \beta_3} + O(v^2).
\end{aligned} \tag{4.48}$$

把这些表达式 (4.47) 与 (4.48) 同第二层相关子 (4.41) 与 (4.43) 比较, 很容易看出, 令耦合为

$$g^{\alpha_1\alpha_2} = G_{(2)}^{\alpha_1\alpha_2} + O\left(\frac{1}{n_1}\right), \tag{4.49}$$

$$v^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} = \frac{1}{n_1} V_{(2)}^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} + O\left(\frac{1}{n_1^2}\right), \tag{4.50}$$

便能在 $1/n_1$ 的领先阶重现第二层预激活量相关子, 其边缘分布为

$$p(z^{(2)} | \mathcal{D}) = \frac{1}{Z} e^{-S(z^{(2)})}, \tag{4.51}$$

作用量则是四次作用量 (4.44). 为方便起见, 这里定义了一个用第二层平均度量之逆升高指标的四点顶点:

$$V_{(2)}^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} \equiv \sum_{\beta_1, \dots, \beta_4} G_{(2)}^{\alpha_1\beta_1} G_{(2)}^{\alpha_2\beta_2} G_{(2)}^{\alpha_3\beta_3} G_{(2)}^{\alpha_4\beta_4} V_{(\beta_1\beta_2)(\beta_3\beta_4)}^{(2)}. \tag{4.52}$$

注意, 四次耦合 v 为 $O(1/n_1)$; 这证明了前面在宽网络中微扰处理该耦合的合理性. 还要注意, 这些耦合——逆度量 $G_{(2)}^{\alpha_1\alpha_2}$ 与四次耦合 $V_{(2)}^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}$ ——依赖输入. 特别地, 神经元之间相互作用的有效强度由送入网络的那组特定输入决定.

至此, 第二层预激活量分布的第一次组合推导完成.

Schwinger–Dyson 法：代数推导

下面给出一种巧妙的方法, 推导第二层预激活量分布的作用量. 把条件分布 (4.35) 代入边缘化方程 (4.34), 第二层边缘分布变成

$$p(z^{(2)} | \mathcal{D}) = \int \left[\prod_{i,\alpha} dz_{i;\alpha}^{(1)} \right] p(z^{(1)} | \mathcal{D}) \frac{\exp\left(-\frac{1}{2} \sum_{j=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \hat{G}_{(2)}^{\alpha_1\alpha_2} z_{j;\alpha_1}^{(2)} z_{j;\alpha_2}^{(2)}\right)}{\sqrt{|2\pi \hat{G}_{(2)}|^{n_2}}}. \tag{4.53}$$

前面已经看到，随机度量可自然地分解为平均部分与涨落部分：

$$\widehat{G}_{\alpha_1\alpha_2}^{(2)} = G_{\alpha_1\alpha_2}^{(2)} + \widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)}. \quad (4.54)$$

把这个矩阵围绕均值按涨落展开到二阶，得到逆随机度量⁴³

$$\begin{aligned} \widehat{G}_{(2)}^{\alpha_1\alpha_2} = & G_{(2)}^{\alpha_1\alpha_2} - \sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(2)}^{\alpha_1\beta_1} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} G_{(2)}^{\beta_2\alpha_2} \\ & + \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} G_{(2)}^{\alpha_1\beta_1} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} G_{(2)}^{\beta_2\beta_3} \widehat{\Delta G}_{\beta_3\beta_4}^{(2)} G_{(2)}^{\beta_4\alpha_2} + O(\Delta^3). \end{aligned} \quad (4.55)$$

把它代入边缘分布 (4.53) 被积函数中的指数，并按涨落 $\widehat{\Delta G}_{\alpha_1\alpha_2}^{(2)}$ 作 Taylor 展开，得到

$$\begin{aligned} & \exp\left(-\frac{1}{2} \sum_{j=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \widehat{G}_{(2)}^{\alpha_1\alpha_2} z_{j;\alpha_1}^{(2)} z_{j;\alpha_2}^{(2)}\right) \\ = & \exp\left(-\frac{1}{2} \sum_{j=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(2)}^{\alpha_1\alpha_2} z_{j;\alpha_1}^{(2)} z_{j;\alpha_2}^{(2)}\right) \\ & \times \left\{ 1 + \frac{1}{2} \sum_{i=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \left(\sum_{\beta_1, \beta_2 \in \mathcal{D}} G_{(2)}^{\alpha_1\beta_1} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} G_{(2)}^{\beta_2\alpha_2} \right) z_{i;\alpha_1}^{(2)} z_{i;\alpha_2}^{(2)} \right. \\ & - \frac{1}{2} \sum_{i=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \left(\sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} G_{(2)}^{\alpha_1\beta_1} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} G_{(2)}^{\beta_2\beta_3} \widehat{\Delta G}_{\beta_3\beta_4}^{(2)} G_{(2)}^{\beta_4\alpha_2} \right) z_{i;\alpha_1}^{(2)} z_{i;\alpha_2}^{(2)} \\ & + \frac{1}{2!} \left(\frac{1}{2}\right)^2 \sum_{i_1, i_2=1}^{n_2} \sum_{\alpha_1, \dots, \beta_4 \in \mathcal{D}} G_{(2)}^{\alpha_1\beta_1} \dots G_{(2)}^{\alpha_4\beta_4} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} \widehat{\Delta G}_{\beta_3\beta_4}^{(2)} \\ & \left. \times z_{i_1;\alpha_1}^{(2)} z_{i_1;\alpha_2}^{(2)} z_{i_2;\alpha_3}^{(2)} z_{i_2;\alpha_4}^{(2)} + O(\Delta^3) \right\}. \end{aligned} \quad (4.56)$$

利用这个表达式，分母中的行列式变成

$$\begin{aligned} & \sqrt{|2\pi \widehat{G}^{(2)}|^{n_2}} = \int \left[\prod_{i, \alpha} dz_{i;\alpha}^{(2)} \right] \exp\left(-\frac{1}{2} \sum_{j=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \widehat{G}_{(2)}^{\alpha_1\alpha_2} z_{j;\alpha_1}^{(2)} z_{j;\alpha_2}^{(2)}\right) \\ = & \sqrt{|2\pi G^{(2)}|^{n_2}} \left[1 + \frac{n_2}{2} \sum_{\beta_1, \beta_2 \in \mathcal{D}} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} G_{(2)}^{\beta_1\beta_2} \right. \\ & \left. + \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} \widehat{\Delta G}_{\beta_1\beta_2}^{(2)} \widehat{\Delta G}_{\beta_3\beta_4}^{(2)} \left(\frac{n_2^2}{8} G_{(2)}^{\beta_1\beta_2} G_{(2)}^{\beta_3\beta_4} - \frac{n_2}{4} G_{(2)}^{\beta_1\beta_3} G_{(2)}^{\beta_2\beta_4} \right) + O(\Delta^3) \right], \end{aligned} \quad (4.57)$$

第一行把行列式重新表示成高斯积分；随后代入 (4.56)，并对第二层预激活量 $z^{(2)}$ 积分。

⁴³这个方程与度量涨落的定义方程 (4.38) 有时合称为 Schwinger–Dyson 方程 [32, 33]，本小节的标题正由此而来。

接下来，把这两个表达式 (4.56) 与 (4.57) 代回第二层分布 (4.53)，便可把第一层预激活量积分掉，得到

$$\begin{aligned}
 p(z^{(2)}|\mathcal{D}) &= \frac{1}{\sqrt{|2\pi G^{(2)}|^{n_2}}} \exp\left(-\frac{1}{2} \sum_{j=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(2)}^{\alpha_1 \alpha_2} z_{j; \alpha_1}^{(2)} z_{j; \alpha_2}^{(2)}\right) \\
 &\quad \times \left\{ \left[1 + O\left(\frac{1}{n_1}\right)\right] + \sum_{i=1}^{n_2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \left[O\left(\frac{1}{n_1}\right)\right] z_{i_1; \alpha_1}^{(2)} z_{i_1; \alpha_2}^{(2)} \right. \\
 &\quad \left. + \frac{1}{8n_1} \sum_{i_1, i_2=1}^{n_2} \sum_{\alpha_1, \dots, \alpha_4 \in \mathcal{D}} V_{(2)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} z_{i_1; \alpha_1}^{(2)} z_{i_1; \alpha_2}^{(2)} z_{i_2; \alpha_3}^{(2)} z_{i_2; \alpha_4}^{(2)} \right\} + O\left(\frac{1}{n_1^2}\right),
 \end{aligned} \tag{4.58}$$

这里用到了度量涨落的期望 $\mathbb{E}[\widehat{\Delta G}_{\beta_1 \beta_2}^{(2)}] = 0$ 与 $\mathbb{E}[\widehat{\Delta G}_{\beta_1 \beta_2}^{(2)} \widehat{\Delta G}_{\beta_3 \beta_4}^{(2)}] = \frac{1}{n_1} V_{(\beta_1 \beta_2)(\beta_3 \beta_4)}^{(2)}$.⁴⁴ 取对数以分离出作用量，并把无关的常数项吸收到配分函数中，便得到第一层宽度领先阶上正确的第二层四次作用量：

$$\begin{aligned}
 S(z) &= \frac{1}{2} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \left[G_{(2)}^{\alpha_1 \alpha_2} + O\left(\frac{1}{n_1}\right) \right] \sum_{i=1}^{n_2} z_{i; \alpha_1} z_{i; \alpha_2} \\
 &\quad - \frac{1}{8} \sum_{\alpha_1, \dots, \alpha_4 \in \mathcal{D}} \frac{1}{n_1} V_{(2)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} \sum_{i_1, i_2=1}^{n_2} z_{i_1; \alpha_1} z_{i_1; \alpha_2} z_{i_2; \alpha_3} z_{i_2; \alpha_4} + O\left(\frac{1}{n_1^2}\right).
 \end{aligned} \tag{4.60}$$

谨慎的读者或许会疑惑：为什么舍弃二次耦合的 $1/n_1$ 修正，却保留同阶的四次耦合？主要原因是，这种修正对二点相关子只给出次领先贡献，而四次耦合对连通四点相关子给出领先贡献。实际上，后面将会遇到多种可观测量，它们的领先贡献完全来自四次耦合诱导的非平凡神经元间相互作用。相比之下，二次耦合的有限宽修正只是很小的定量效应。尽管如此，为了完整起见，我们仍将在 §4.5 中计算这一修正。⁴⁵

近高斯作用量的应用

完成两种推导之后，在进入下一节之前，借此机会进一步熟悉如何对近高斯分布作计算。与上一节对高斯作用量的处理相呼应，这里计算同一神经元上两个激活的期望，

⁴⁴这里默认假设 $\widehat{\Delta G}^{m \geq 3}$ 的期望为 $O(1/n_1^2)$ 或更高阶。例如，完全沿用 (4.40) 中的步骤，可计算

$$\begin{aligned}
 &\mathbb{E} \left[\widehat{\Delta G}_{\beta_1 \beta_2}^{(2)} \widehat{\Delta G}_{\beta_3 \beta_4}^{(2)} \widehat{\Delta G}_{\beta_5 \beta_6}^{(2)} \right] \\
 &= \frac{1}{n_1^2} \left(C_W^{(2)} \right)^3 \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \sigma_{\alpha_5} \sigma_{\alpha_6} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \sigma_{\alpha_5} \sigma_{\alpha_6} \rangle_{G^{(1)}} \right. \\
 &\quad - \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \langle \sigma_{\alpha_5} \sigma_{\alpha_6} \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_5} \sigma_{\alpha_6} \rangle_{G^{(1)}} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \\
 &\quad \left. + 2 \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \langle \sigma_{\alpha_5} \sigma_{\alpha_6} \rangle_{G^{(1)}} \right].
 \end{aligned} \tag{4.59}$$

与 (4.40) 的中间步骤一样，这里不难注意到，只有所有神经元指标都相同时才有非零贡献。进一步利用同一观察，可以证明 $\mathbb{E} \left[\left(\widehat{\Delta G}^{(2)} \right)^m \right] = O(1/n_1^{m-1})$ 。

⁴⁵后面还会看到 (§5.4)，通过微调初始化超参数，与近高斯修正相比，这些次领先修正会随深度受到抑制；因而在某种意义上，二次耦合的这个次领先修正可以被双重忽略。

以及四个激活的期望；对于后者，四个激活可以全在同一神经元上，也可以成对位于不同神经元上。所得表达式将帮助我们求出更深层中的预激活量分布。

下面只是应用一般函数期望的公式 (4.46)。这些表达式对任意层 $\ell > 1$ 都成立。首先，对于同一神经元上的两个激活，有

$$\begin{aligned} & \mathbb{E}[\sigma(z_{i_1;\alpha_1}) \sigma(z_{i_1;\alpha_2})] \\ &= \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_g + \frac{1}{8} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \\ & \quad \times \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) (z_{\beta_3} z_{\beta_4} - g_{\beta_3 \beta_4}) \rangle_g \right. \\ & \quad \left. + 2n \langle \sigma_{\alpha_1} \sigma_{\alpha_2} (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) \rangle_g g_{\beta_3 \beta_4} - 2 \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_g g_{\beta_1 \beta_3} g_{\beta_2 \beta_4} \right] + O(v^2), \end{aligned} \quad (4.61)$$

这里假设读者已经充分熟悉高斯积分与按不同神经元因子化的操作，因此省略中间步骤。这个结果突出表明，加入四次耦合 v ，即使对同一神经元激活的二点相关子也有非平凡影响。类似地，可以计算同一神经元上四个激活的期望；但这里只需要领先高斯贡献，即

$$\begin{aligned} & \mathbb{E}[\sigma(z_{i_1;\alpha_1}) \sigma(z_{i_1;\alpha_2}) \sigma(z_{i_1;\alpha_3}) \sigma(z_{i_1;\alpha_4})] - \mathbb{E}[\sigma(z_{i_1;\alpha_1}) \sigma(z_{i_1;\alpha_2})] \mathbb{E}[\sigma(z_{i_1;\alpha_3}) \sigma(z_{i_1;\alpha_4})] \\ &= \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_g - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_g \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_g + O(v), \end{aligned} \quad (4.62)$$

这里减去了二点相关子的贡献，因为下一节中将会出现的正是这个组合。

最后，把一般函数期望公式 (4.46) 与高斯期望中的神经元因子化用于分别位于两个不同神经元 $i_1 \neq i_2$ 上的两对激活，得到

$$\begin{aligned} & \mathbb{E}[\sigma(z_{i_1;\alpha_1}) \sigma(z_{i_1;\alpha_2}) \sigma(z_{i_2;\alpha_3}) \sigma(z_{i_2;\alpha_4})] - \mathbb{E}[\sigma(z_{i_1;\alpha_1}) \sigma(z_{i_1;\alpha_2})] \mathbb{E}[\sigma(z_{i_2;\alpha_3}) \sigma(z_{i_2;\alpha_4})] \\ &= \frac{1}{8} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \sum_{j_1, j_2=1}^n \\ & \quad \times \left[\langle \langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} \sigma_{i_1;\alpha_1} \sigma_{i_1;\alpha_2} \sigma_{i_2;\alpha_3} \sigma_{i_2;\alpha_4} \rangle \rangle_g \right. \\ & \quad - \langle \langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} \sigma_{i_1;\alpha_1} \sigma_{i_1;\alpha_2} \rangle \rangle_g \langle \langle \sigma_{i_2;\alpha_3} \sigma_{i_2;\alpha_4} \rangle \rangle_g \\ & \quad - \langle \langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} \sigma_{i_2;\alpha_3} \sigma_{i_2;\alpha_4} \rangle \rangle_g \langle \langle \sigma_{i_1;\alpha_1} \sigma_{i_1;\alpha_2} \rangle \rangle_g \\ & \quad \left. + \langle \langle z_{j_1;\beta_1} z_{j_1;\beta_2} z_{j_2;\beta_3} z_{j_2;\beta_4} \rangle \rangle_g \langle \langle \sigma_{i_1;\alpha_1} \sigma_{i_1;\alpha_2} \rangle \rangle_g \langle \langle \sigma_{i_2;\alpha_3} \sigma_{i_2;\alpha_4} \rangle \rangle_g \right], \\ &= \frac{1}{4} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) \rangle_g \langle \sigma_{\alpha_3} \sigma_{\alpha_4} (z_{\beta_3} z_{\beta_4} - g_{\beta_3 \beta_4}) \rangle_g + O(v^2), \end{aligned} \quad (4.63)$$

其中仅当 $j_1 = i_1$ 且 $j_2 = i_2$ ，或 $j_1 = i_2$ 且 $j_2 = i_1$ 时，才有非零贡献。这说明，只有在作用量中加入四次耦合，激活对之间才会产生相关性，暗示了有限宽在特征学习中的作用。

更一般地，考虑分别依赖于样本集 $\mathcal{A}_1$ 与 $\mathcal{A}_2 \subset \mathcal{D}$ 的预激活量函数 $\mathcal{F}(z_{i_1;\mathcal{A}_1})$ 与 $\mathcal{G}(z_{i_2;\mathcal{A}_2})$ ；这里稍微滥用记号，把对集合的依赖写进下标。对不同神经元 $i_1 \neq i_2$ ，与上

面完全相同的计算表明，它们的协方差为

$$\begin{aligned} & \text{Cov}[\mathcal{F}(z_{i_1; \mathcal{A}_1}), \mathcal{G}(z_{i_2; \mathcal{A}_2})] \\ & \equiv \mathbb{E}[\mathcal{F}(z_{i_1; \mathcal{A}_1}) \mathcal{G}(z_{i_2; \mathcal{A}_2})] - \mathbb{E}[\mathcal{F}(z_{i_1; \mathcal{A}_1})] \mathbb{E}[\mathcal{G}(z_{i_2; \mathcal{A}_2})], \\ & = \frac{1}{4} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \left\langle (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) \mathcal{F}(z_{\mathcal{A}_1}) \right\rangle_g \left\langle (z_{\beta_3} z_{\beta_4} - g_{\beta_3 \beta_4}) \mathcal{G}(z_{\mathcal{A}_2}) \right\rangle_g + O(v^2). \end{aligned} \quad (4.64)$$

这个公式以后会非常有用。

4.3 更深层：非高斯性的累积

更深层中的预激活量递归地由下式给出：

$$z_{i; \alpha}^{(\ell+1)} = b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma_{j; \alpha}^{(\ell)}, \quad \text{其中 } i = 1, \dots, n_{\ell+1}, \quad (4.65)$$

上一层激活简写为

$$\sigma_{i; \alpha}^{(\ell)} \equiv \sigma(z_{i; \alpha}^{(\ell)}). \quad (4.66)$$

沿用求第二层分布时实施的步骤，可以得到这些更深层中预激活量的边缘分布，包括输出分布 $p(z^{(L)} | \mathcal{D})$ 。唯一的复杂之处在于，前一层的预激活量分布不再像第一层那样是高斯分布。

这一推导有三个关键概念：递归、作用量与 $1/n$ 展开。下面依次讨论。

递归

递归的思想是从第 ℓ 层边缘分布 $p(z^{(\ell)} | \mathcal{D})$ 所含的信息出发，得到第 $(\ell+1)$ 层的边缘分布。为刻画边缘预激活量分布逐层的变化，首先写出相邻 ℓ 层与 $\ell+1$ 层预激活量的联合概率分布

$$p(z^{(\ell+1)}, z^{(\ell)} | \mathcal{D}) = p(z^{(\ell+1)} | z^{(\ell)}) p(z^{(\ell)} | \mathcal{D}), \quad (4.67)$$

再计算条件概率分布 $p(z^{(\ell+1)} | z^{(\ell)})$ ，最后对第 ℓ 层预激活量作边缘化：

$$p(z^{(\ell+1)} | \mathcal{D}) = \int \left[\prod_{i, \alpha} dz_{i; \alpha}^{(\ell)} \right] p(z^{(\ell+1)} | z^{(\ell)}) p(z^{(\ell)} | \mathcal{D}). \quad (4.68)$$

特别地，条件概率分布 $p(z^{(\ell+1)} | z^{(\ell)})$ 起到**转移矩阵**的作用，连接相邻层的预激活量分布。

这个条件分布的计算，与第一层所做的计算 (4.16) 以及随后改用于第二层条件分布的计算 (4.33) 完全相同。如果愿意，可以再次沿着 §4.1 的步骤，把 $z^{(1)}$ 换成 $z^{(\ell+1)}$ ，

把 $x_{j;\alpha}$ 换成 $\sigma_{j;\alpha}^{(\ell)}$, 得到

$$p\left(z^{(\ell+1)} \middle| z^{(\ell)}\right) = \frac{1}{\sqrt{|2\pi\widehat{G}^{(\ell+1)}|^{n_{\ell+1}}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_{\ell+1}} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \widehat{G}_{(\ell+1)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(\ell+1)} z_{i;\alpha_2}^{(\ell+1)}\right), \quad (4.69)$$

其中第 $(\ell+1)$ 层随机度量 为

$$\widehat{G}_{\alpha_1 \alpha_2}^{(\ell+1)} \equiv C_b^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \quad (4.70)$$

它通过激活 $\sigma^{(\ell)}$ 依赖前一层 ℓ 中的随机变量 $z^{(\ell)}$. 注意, 含奇数个第 $(\ell+1)$ 层预激活量的所有相关子都为零, 而偶点相关子由 Wick 缩并得到:

$$\mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell+1)} \cdots z_{i_{2m}; \alpha_{2m}}^{(\ell+1)} \right] = \sum_{\text{所有配对}} \delta_{i_{k_1} i_{k_2}} \cdots \delta_{i_{k_{2m-1}} i_{k_{2m}}} \mathbb{E} \left[\widehat{G}_{\alpha_{k_1} \alpha_{k_2}}^{(\ell+1)} \cdots \widehat{G}_{\alpha_{k_{2m-1}} \alpha_{k_{2m}}}^{(\ell+1)} \right], \quad (4.71)$$

其中求和遍历辅助指标 $(k_1, \dots, k_{2m})$ 的所有 $(2m-1)!!$ 种配对. 左边的期望刻画第 $(\ell+1)$ 层预激活量分布; 右边代入随机度量 (4.70) 后, 期望变成第 ℓ 层激活的相关子, 可以用第 ℓ 层分布计算.

随机度量的均值为

$$G_{\alpha_1 \alpha_2}^{(\ell+1)} \equiv \mathbb{E} \left[\widehat{G}_{\alpha_1 \alpha_2}^{(\ell+1)} \right] = C_b^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right], \quad (4.72)$$

这个平均度量通过

$$\mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)} \right] = \delta_{i_1 i_2} \mathbb{E} \left[\widehat{G}_{\alpha_1 \alpha_2}^{(\ell+1)} \right] = \delta_{i_1 i_2} G_{\alpha_1 \alpha_2}^{(\ell+1)}, \quad (4.73)$$

控制第 $(\ell+1)$ 层的二点相关子; 前面的第二层结果 (4.41) 正是一般方程 (4.71) 的特例. 同时, 围绕均值的涨落

$$\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \equiv \widehat{G}_{\alpha_1 \alpha_2}^{(\ell+1)} - G_{\alpha_1 \alpha_2}^{(\ell+1)} = C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \left(\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right] \right), \quad (4.74)$$

显然均值为零:

$$\mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \right] = 0. \quad (4.75)$$

它的大小为

$$\frac{1}{n_\ell} V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)} \equiv \mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Delta G}_{\alpha_3 \alpha_4}^{(\ell+1)} \right] = \mathbb{E} \left[\widehat{G}_{\alpha_1 \alpha_2}^{(\ell+1)} \widehat{G}_{\alpha_3 \alpha_4}^{(\ell+1)} \right] - G_{\alpha_1 \alpha_2}^{(\ell+1)} G_{\alpha_3 \alpha_4}^{(\ell+1)}. \quad (4.76)$$

这里引入了第 $(\ell+1)$ 层四点顶点 $V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)}$, 它推广了第二层四点顶点 (4.40), 并控制第 $(\ell+1)$ 层的连通四点相关子. 具体而言, 沿用第二层的操作——参见 (4.42) 与 (4.43)——或直接应用一般表达式 (4.71), 可得

$$\begin{aligned} & \mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)} z_{i_3; \alpha_3}^{(\ell+1)} z_{i_4; \alpha_4}^{(\ell+1)} \right] \Big|_{\text{connected}} \\ &= \frac{1}{n_\ell} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)} + \delta_{i_1 i_3} \delta_{i_2 i_4} V_{(\alpha_1 \alpha_3)(\alpha_2 \alpha_4)}^{(\ell+1)} + \delta_{i_1 i_4} \delta_{i_2 i_3} V_{(\alpha_1 \alpha_4)(\alpha_2 \alpha_3)}^{(\ell+1)} \right]. \end{aligned} \quad (4.77)$$

概括来说，目前已经用第 ℓ 层激活相关子表示了第 $(\ell + 1)$ 层预激活量的二点相关子 (4.73) 与连通四点相关子 (4.77)；若有需要，还可用 (4.71) 得到高阶相关子的相应表达式。递归方法的策略是：给定第 ℓ 层分布 $p(z^{(\ell)}|\mathcal{D})$ ，先计算第 ℓ 层激活相关子，由此得到第 $(\ell + 1)$ 层预激活量相关子；再用这些相关子重建第 $(\ell + 1)$ 层边缘分布 $p(z^{(\ell+1)}|\mathcal{D})$ 。借助作用量，可以高效实现第 ℓ 层激活相关子的计算与第 $(\ell + 1)$ 层分布的重建。

作用量

预激活量分布 $p(z^{(\ell)}|\mathcal{D})$ 可以用作用量写成

$$p(z^{(\ell)}|\mathcal{D}) = \frac{e^{-S(z^{(\ell)})}}{Z(\ell)}, \quad (4.78)$$

其中第 ℓ 层的配分函数为

$$Z(\ell) \equiv \int \left[\prod_{i,\alpha} dz_{i;\alpha}^{(\ell)} \right] e^{-S(z^{(\ell)})}, \quad (4.79)$$

而作用量的拟设由下列展开给出：

$$\begin{aligned} S(z^{(\ell)}) \equiv & \frac{1}{2} \sum_{i=1}^{n_\ell} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} g_{(\ell)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(\ell)} z_{i;\alpha_2}^{(\ell)} \\ & - \frac{1}{8} \sum_{i_1, i_2=1}^{n_\ell} \sum_{\alpha_1, \dots, \alpha_4 \in \mathcal{D}} v_{(\ell)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} z_{i_1;\alpha_1}^{(\ell)} z_{i_1;\alpha_2}^{(\ell)} z_{i_2;\alpha_3}^{(\ell)} z_{i_2;\alpha_4}^{(\ell)} + \dots \end{aligned} \quad (4.80)$$

这个拟设既包含 §4.1 中第一层预激活量的作用量——其中 $g_{(1)}^{\alpha_1 \alpha_2} = G_{(1)}^{\alpha_1 \alpha_2}$ 且 $v_{(1)} = 0$ ——也包含 §4.2 中第二层预激活量的作用量——其耦合 $g_{(2)}$ 与 $v_{(2)}$ 分别由 (4.49) 和 (4.50) 给出。实际上，给定预激活量相关子 (4.71) 的对称性，这是围绕高斯作用量最一般的展开。特别地，由于已知含奇数个预激活量的相关子为零，作用量中只会出现预激活量的偶次幂。

这里，系数 $g_{(\ell)}^{\alpha_1 \alpha_2}$ 、 $v_{(\ell)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}$ 以及展开中隐含的其他项，都是共同控制神经预激活量相互作用的数据依赖耦合，并且与预激活量 $z^{(\ell)}$ 的相关子有简单关系。特别地，在 §4.2 中，我们给出了二次、四次耦合与二点、四点相关子之间关系的两种推导。同样的论证适用于任意层 ℓ ，因此

$$g_{(\ell)}^{\alpha_1 \alpha_2} = G_{(\ell)}^{\alpha_1 \alpha_2} + O(v, \dots), \quad (4.81)$$

$$v_{(\ell)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} = \frac{1}{n_{\ell-1}} V_{(\ell)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} + O(v^2, \dots), \quad (4.82)$$

其中应理解，四点顶点的升高指标是与第 ℓ 层逆度量缩并的简写：

$$V_{(\ell)}^{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)} \equiv \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} G_{(\ell)}^{\alpha_1 \beta_1} G_{(\ell)}^{\alpha_2 \beta_2} G_{(\ell)}^{\alpha_3 \beta_3} G_{(\ell)}^{\alpha_4 \beta_4} V_{(\beta_1 \beta_2)(\beta_3 \beta_4)}^{(\ell)}. \quad (4.83)$$

注意，当且仅当四次耦合 v 与更高阶耦合在微扰意义下很小时，才能自洽地忽略 (4.81) 与 (4.82) 中的高阶项 $O(\dots)$ 。当网络足够宽时，实际情况的确如此，下面就会证明。

大宽度展开

现在，任务已经明确。首先注意，相关子与耦合之间的映射 (4.81) 和 (4.82)，已经完成递归策略中提到的一项任务：将它们用于第 $(\ell + 1)$ 层时，可以从第 $(\ell + 1)$ 层预激活量相关子重建第 $(\ell + 1)$ 层分布。剩下的任务只是利用第 ℓ 层作用量 (4.80)，计算第 ℓ 层激活 $\sigma^{(\ell)}$ 的期望；这些期望出现在第 $(\ell + 1)$ 层预激活量 $z^{(\ell+1)}$ 的二点相关子 (4.73) 与四点相关子 (4.77) 的表达式中。

在每层神经元数都很大的宽网络区域，这些计算会简化：

$$n_1, n_2, \dots, n_{L-1} \sim n \gg 1. \quad (4.84)$$

正如前面一直强调的，这个大而有限的宽度区域使网络既能在实践中使用，又能在理论上处理。具体而言，相关子与耦合的关系 (4.81) 和 (4.82) 在该区域会简化，而高阶非高斯修正可以按 $1/n$ 级数作自洽截断。⁴⁶ 更准确地说，作归纳假设：第 ℓ 层的平均度量 $G^{(\ell)} = O(1)$ 与四点顶点 $V^{(\ell)} = O(1)$ 都是一阶量——第一层与第二层确实如此——并证明第 $(\ell + 1)$ 层仍然成立。由 (4.81) 和 (4.82)，这一归纳假设特别意味着第 ℓ 层的四次耦合 $v_{(\ell)} = O(1/n)$ 在微扰意义下很小，而二次耦合为 $g_{(\ell)} = G_{(\ell)} + O(1/n)$ 。在完成这项归纳证明的同时，也会得到控制预激活量分布从第 ℓ 层到第 $(\ell + 1)$ 层变化的递归关系。

首先，第 $(\ell + 1)$ 层二点相关子 (4.73) 直接由度量给出：

$$G_{\alpha_1 \alpha_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right]. \quad (4.85)$$

上一节已经预先计算了这个特定的激活二点相关子 (4.61)。代入该结果，再结合二次耦合 $g_{(\ell)} = G_{(\ell)} + O(1/n)$ 与四次耦合 $v_{(\ell)} = O(1/n)$ ，得到

$$G_{\alpha_1 \alpha_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right), \quad (4.86)$$

这就是预激活量二点相关子的领先递归。⁴⁷ 这个结果是自洽的：任意一阶度量 $G^{(\ell)}$ 都会在下一层产生一阶度量 $G^{(\ell+1)}$ 。修正受到 $O(1/n)$ 抑制，只影响二次耦合 $g_{(\ell+1)} = G_{(\ell+1)} + O(1/n)$ 的次领先项。还要注意，若忽略次领先的 $1/n$ 修正并用 g 替换 G ，二点相关子的递归 (4.86) 也可以视为二次耦合的领先递归。

接着计算四点相关子 (4.77)，这需要计算度量涨落的大小 (4.76)。代入第 $(\ell + 1)$ 层度量涨落的一般表达式 (4.74)，得到

$$\begin{aligned} & \frac{1}{n_\ell} V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)} \\ &= \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{j,k=1}^{n_\ell} \left\{ \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \right\}. \end{aligned} \quad (4.87)$$

⁴⁶ 用 §4.6 的语言说，这种截断在 RG 流下得到保持。

⁴⁷ 注意，与 §4.2 中第二层计算的区别仅在于，(4.85) 中的期望并非严格高斯，而是带有 $1/n$ 修正。这突出了本节与第二层计算的主要区别：前一层的分布是近高斯的。

这里有两类贡献：来自重合神经元的贡献，以及来自不同神经元对的贡献。上一节同样预先计算了这两类四点激活相关子。当四个激活全都重合，即 $j = k$ 时，代入 (4.62)，得到

$$\begin{aligned} & \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{j;\alpha_3}^{(\ell)} \sigma_{j;\alpha_4}^{(\ell)} \right] - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\sigma_{j;\alpha_3}^{(\ell)} \sigma_{j;\alpha_4}^{(\ell)} \right] \\ &= \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(\ell)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right), \end{aligned} \quad (4.88)$$

其中依据第 ℓ 层的归纳假设截断到 $1/n$ 的领先阶。另一方面，当 $j \neq k$ ，相关性发生在两个神经元之间时，代入表达式 (4.63)，得到

$$\begin{aligned} & \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ &= \frac{1}{4n_{\ell-1}} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} V_{(\ell)}^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) \rangle_{G^{(\ell)}} \\ & \quad \times \langle \sigma_{\alpha_3} \sigma_{\alpha_4} (z_{\beta_3} z_{\beta_4} - g_{\beta_3 \beta_4}) \rangle_{G^{(\ell)}} + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (4.89)$$

这里再次利用归纳假设，在大宽度展开中截断到领先阶。⁴⁸ 把这两个表达式代回 (4.87) 并完成求和，得到四点顶点的递归：

$$\begin{aligned} & \frac{1}{n_\ell} V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)} \\ &= \frac{1}{n_\ell} \left(C_W^{(\ell+1)} \right)^2 [\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(\ell)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(\ell)}}], \\ & \quad + \frac{1}{n_{\ell-1}} \frac{\left(C_W^{(\ell+1)} \right)^2}{4} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} V_{(\ell)}^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} (z_{\beta_1} z_{\beta_2} - g_{\beta_1 \beta_2}) \rangle_{G^{(\ell)}} \\ & \quad \times \langle \sigma_{\alpha_3} \sigma_{\alpha_4} (z_{\beta_3} z_{\beta_4} - g_{\beta_3 \beta_4}) \rangle_{G^{(\ell)}} + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (4.90)$$

重要的是，可以看出

$$\frac{1}{n_\ell} V^{(\ell+1)} = O\left(\frac{1}{n}\right), \quad (4.91)$$

并且 $V^{(\ell+1)} = O(1)$ ；由此完成归纳证明，也结束了二点与四点相关子的递归关系 (4.86) 和 (4.90) 的推导。与二次耦合的情形一样，若忽略次领先的 $1/n^2$ 修正，并用 g 替换 G 、用 v 替换 V ，连通四点相关子的递归 (4.90) 也可以视为四次耦合的递归。

注意，在严格的 $n \rightarrow \infty$ 极限中，四次耦合消失，所有层 ℓ 的预激活量边缘分布 $p(z^{(\ell)} | \mathcal{D})$ 都是高斯分布。对这个无限宽极限的第一个非平凡修正，可通过研究耦合为 $v_{(\ell)}$ 的四次作用量来刻画。下文将主要关注具有这个四次作用量的有效理论，因为二次作用量所描述的网络与四次作用量所描述的网络，在行为上预计会有显著的定性差异。作用量中高阶项给出的其他有限宽修正可以改变量化结果，但通常不应产生定性差异。

⁴⁸与第二层计算的区别仍然在于：在 §4.2 中，这些期望是对严格高斯的第一层分布取的。此时，所有神经元重合的情形会产生 (4.88) 形式的贡献，但两个神经元的情形不会产生 (4.89) 形式的贡献——参见 (4.40)。

4.4 边缘化规则

在前面几节中，递归的每一步都对给定层中的所有预激活量作了边缘化。本节汇集关于其他部分边缘化的两点说明，而不是积分掉整个层。具体而言，将讨论对数据集 $\mathcal{D}$ 中 ND 个样本的一个子集作边缘化，以及对一层中神经元的一个子集作边缘化。

粗略地说，这些边缘化让我们只关注感兴趣的特定输入数据与神经元。严格地说，考虑计算函数 $F(z_{I;\mathcal{A}}) = F(\{z_{i;\alpha}\}_{i \in I; \alpha \in \mathcal{A}})$ 的期望；它依赖子样本集 $\mathcal{A} \subset \mathcal{D}$ 与第 ℓ 层中的神经元子集 $I \subset \{1, \dots, n_\ell\} \equiv \mathcal{N}$ 。这里稍微滥用记号，把对集合的依赖写进下标。于是

$$\begin{aligned}
 & \mathbb{E}[F(z_{I;\mathcal{A}})] \\
 &= \int \left[\prod_{i \in \mathcal{N}} \prod_{\alpha \in \mathcal{D}} dz_{i;\alpha} \right] F(z_{I;\mathcal{A}}) p(z_{\mathcal{N};\mathcal{D}} | \mathcal{D}) \\
 &= \int \left[\prod_{i \in I} \prod_{\alpha \in \mathcal{A}} dz_{i;\alpha} \right] F(z_{I;\mathcal{A}}) \left\{ \int \left[\prod_{(j;\beta) \in [\mathcal{N} \times \mathcal{D} - I \times \mathcal{A}]} dz_{j;\beta} \right] p(z_{\mathcal{N};\mathcal{D}} | \mathcal{D}) \right\} \\
 &= \int \left[\prod_{i \in I} \prod_{\alpha \in \mathcal{A}} dz_{i;\alpha} \right] F(z_{I;\mathcal{A}}) p(z_{I;\mathcal{A}} | \mathcal{A})
 \end{aligned} \tag{4.92}$$

最后一个等号只是对不进入感兴趣可观测量的旁观变量作边缘化，并且在某种意义上定义了子采样、子神经元分布：

$$p(z_{I;\mathcal{A}} | \mathcal{A}) \equiv \int \left[\prod_{(j;\beta) \in [\mathcal{N} \times \mathcal{D} - I \times \mathcal{A}]} dz_{j;\beta} \right] p(z_{\mathcal{N};\mathcal{D}} | \mathcal{D}). \tag{4.93}$$

换言之，计算函数 $F(z_{I;\mathcal{A}})$ 的期望时，可以把完整分布 $p(z_{\mathcal{N};\mathcal{D}} | \mathcal{D})$ 直接限制到子样本集 $\mathcal{A}$ 与子神经元集 I 上的分布，即 $p(z_{I;\mathcal{A}} | \mathcal{A})$ 。我们把这个性质称为**边缘化规则**。没错，这多少有些平凡——只是重述概率分布关于边缘化的一致性——但它对我们有两个相当有用的推论。

对样本边缘化

边缘化规则的第一个推论是，可以把对数据集中所有样本的巨大积分，约化为只对少数几个样本的紧凑积分。例如，在通过

$$\mathbb{E} \left[z_{i_1;\alpha_1}^{(\ell+1)} z_{i_2;\alpha_2}^{(\ell+1)} \right] = \delta_{i_1 i_2} \left[C_b^{(\ell+1)} + C_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right) \right], \tag{4.94}$$

递归求二点相关子时，可以把带有 $N_{\mathcal{D}} \times N_{\mathcal{D}}$ 方差矩阵 $G^{(\ell)}$ 的 $N_{\mathcal{D}}$ 维高斯积分 $\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}}$ ，约化为由 α_1 与 α_2 张成的 2×2 子矩阵上的易处理二维积分；若 $\alpha_1 = \alpha_2$ ，则约化为一维积分。类似地，四点顶点递归中出现的四激活高斯积分 $\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(\ell)}}$ ，至多涉及四个变量的积分。

一般而言, 用作用量 (4.80) 计算某个具体期望时, 作用量中对整个数据集 $\mathcal{D}$ 的求和, 可以限制到实际出现在该期望中的输入数据子集. 同理, 通过递归 (4.90) 递归计算四点顶点 $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell+1)}$ 时, 右边对数据集 $\mathcal{D}$ 的求和可以限制到发生相关的样本集合 $\{\alpha_1, \alpha_2, \alpha_3, \alpha_4\}$. 但要记住, 在 (4.83) 中构造 $V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)}$ 所用的逆度量, 此时必须取为该受限子空间上度量量子矩阵的逆.⁴⁹

对神经元边缘化

第二个推论涉及积分掉一层中的神经元子集. 谨慎的读者或许已经担心, 第 ℓ 层作用量中的四次项

$$-\frac{1}{8} \sum_{i_1, i_2=1}^{n_\ell} \sum_{\alpha_1, \dots, \alpha_4 \in \mathcal{D}} v_{(\ell)}^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} z_{i_1; \alpha_1}^{(\ell)} z_{i_1; \alpha_2}^{(\ell)} z_{i_2; \alpha_3}^{(\ell)} z_{i_2; \alpha_4}^{(\ell)}, \quad (4.95)$$

朴素看来按 $\sim n_\ell^2/n_{\ell-1} = O(n)$ 标度, 因为有两个对 n_ℓ 的求和, 而且由 (4.82) 已知耦合 $v_{(\ell)}$ 按 $\sim 1/n_{\ell-1}$ 标度. 类似地, 二次项

$$\frac{1}{2} \sum_{i=1}^{n_\ell} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} g_{(\ell)}^{\alpha_1\alpha_2} z_{i; \alpha_1}^{(\ell)} z_{i; \alpha_2}^{(\ell)}, \quad (4.96)$$

只有一个对 n_ℓ 的求和, 因此朴素看来也为 $O(n)$. 这似乎意味着, 相比二次项, 四次项并未受到微扰抑制, 从而对我们的微扰方法提出质疑.

首先观察到, 这个问题在最终层 $\ell = L$ 永远不会出现, 因为输出维数 n_L 从来都不是参数意义下的大量: 二次项按 $\sim n_L = O(1)$ 标度, 而四次项按 $\sim n_L^2/n_{L-1} = O(1/n)$ 标度, 因而受到微扰抑制.

这一观察与边缘化规则结合, 给出了隐藏层中上述朴素标度计数问题的解法. 实际上, 到目前为止计算的所有期望——无论预激活量还是激活相关子——在任意给定层 ℓ 中, 每个都只涉及少数 m_ℓ 个神经元, 其中 $m_\ell \ll n_\ell$. 这一点总会成立; 实际上不可能一次让无限多个神经元发生相关!

因此, 在第 ℓ 层使用概率分布的作用量表示 (4.80) 计算这些相关子时, 可以先用边缘化规则 (4.92), 积分掉不参与计算的 $(n_\ell - m_\ell)$ 个旁观神经元, 只关注实际出现在期望中的 m_ℓ 个相关神经元. 这样又能把对 n_ℓ 个神经元的求和, 替换为对 m_ℓ 个神经元的求和.⁵⁰

与此同时, 为得到第 ℓ 层的作用量表示, 前面各层中的神经元数 $n_1, \dots, n_{\ell-1}$ 已经被积分掉, 而它们确实在参数意义下很大. 这意味着, 第 ℓ 层作用量中的二次项约化到 m_ℓ 个相关神经元后, 按 $\sim m_\ell = O(1)$ 标度; 四次项则按 $\sim m_\ell^2/n_{\ell-1} = O(1/n)$ 标度. 因而, 非高斯性可以得到微扰处理.

⁴⁹同样的求和限制也可以用于其他任意递归; 当尝试以数值或解析方式计算这些递归时, 它会特别有用.

⁵⁰计算一般期望值, 例如 (4.46) 时, 总能检查出, $(n_\ell - m_\ell)$ 个旁观神经元的贡献在 $1/n_{\ell-1}$ 展开的每一阶都自洽地抵消. 如果翻回补齐我们计算行间小步骤的个人笔记, 必定会注意到这种由高斯因子化造成的抵消.

部分边缘化下的跑动耦合

当只关注样本或神经元的一个子集时，需要调节作用量中的数据依赖耦合。由于耦合的这种跑动很有启发性，并且后续计算也会需要它，这里说明二次耦合 $g_{(\ell),m_\ell}^{\alpha_1\alpha_2}$ 如何依赖作用量中的神经元数 m_ℓ 。

为了简化说明，专门考虑单个输入 x ，并略去所有样本指标。把 m_ℓ 个神经元上的分布记为

$$\begin{aligned} p(z_1^{(\ell)}, \dots, z_{m_\ell}^{(\ell)}) &\propto e^{-S(z_1^{(\ell)}, \dots, z_{m_\ell}^{(\ell)})} \\ &= \exp \left[-\frac{g_{(\ell),m_\ell}}{2} \sum_{j=1}^{m_\ell} z_j^{(\ell)} z_j^{(\ell)} + \frac{v_{(\ell)}}{8} \sum_{j_1, j_2=1}^{m_\ell} z_{j_1}^{(\ell)} z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_2}^{(\ell)} \right], \end{aligned} \quad (4.97)$$

这仍由一直使用的同一作用量 (4.80) 表示，只是现在显式写出了二次耦合对 m_ℓ 的依赖。⁵¹ 下面用两种方法说明二次耦合 $g_{(\ell),m_\ell}$ 如何随 m_ℓ 跑动。

第一种方法从 n_ℓ 个神经元的作用量开始，形式上积分掉 $(n_\ell - m_\ell)$ 个神经元。不失一般性，积分掉最后 $(n_\ell - m_\ell)$ 个神经元，留下标记为 $1, \dots, m_\ell$ 的前 m_ℓ 个神经元。利用边缘化规则 (4.93)，有

$$\begin{aligned} e^{-S(z_1^{(\ell)}, \dots, z_{m_\ell}^{(\ell)})} &\propto p(z_1^{(\ell)}, \dots, z_{m_\ell}^{(\ell)}) = \int dz_{m_\ell+1}^{(\ell)} \cdots dz_{n_\ell}^{(\ell)} p(z_1^{(\ell)}, \dots, z_{n_\ell}^{(\ell)}) \\ &\propto \int dz_{m_\ell+1}^{(\ell)} \cdots dz_{n_\ell}^{(\ell)} \exp \left[-\frac{g_{(\ell),n_\ell}}{2} \sum_{i=1}^{n_\ell} z_i^{(\ell)} z_i^{(\ell)} + \frac{v_{(\ell)}}{8} \sum_{i_1, i_2=1}^{n_\ell} z_{i_1}^{(\ell)} z_{i_1}^{(\ell)} z_{i_2}^{(\ell)} z_{i_2}^{(\ell)} \right], \end{aligned} \quad (4.98)$$

这里始终忽略了与耦合跑动无关的归一化因子。接下来，分离出对 m_ℓ 个神经元的依赖，按四次耦合微扰展开被积函数，最后计算几个简单的高斯积分，积分掉最后 $(n_\ell - m_\ell)$

⁵¹原则上，四次耦合也应依赖 m_ℓ ，即 $v_{(\ell)} \rightarrow v_{(\ell),m_\ell}$ 。但这种依赖只在 v 的高阶才出现，因此略去。

个神经元:

$$\begin{aligned}
 & p(z_1^{(\ell)}, \dots, z_{m_\ell}^{(\ell)}) \\
 & \propto \exp \left[-\frac{g^{(\ell), n_\ell}}{2} \sum_{j=1}^{m_\ell} z_j^{(\ell)} z_j^{(\ell)} + \frac{v^{(\ell)}}{8} \sum_{j_1, j_2=1}^{m_\ell} z_{j_1}^{(\ell)} z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_2}^{(\ell)} \right] \\
 & \times \int dz_{m_\ell+1}^{(\ell)} \cdots dz_{n_\ell}^{(\ell)} \exp \left[-\frac{g^{(\ell), n_\ell}}{2} \sum_{k=m_\ell+1}^{n_\ell} z_k^{(\ell)} z_k^{(\ell)} \right] \\
 & \times \left[1 + \frac{2v^{(\ell)}}{8} \sum_{j=1}^{m_\ell} \sum_{k=m_\ell+1}^{n_\ell} z_j^{(\ell)} z_j^{(\ell)} z_k^{(\ell)} z_k^{(\ell)} \right. \\
 & \quad \left. + \frac{v^{(\ell)}}{8} \sum_{k_1, k_2=m_\ell+1}^{n_\ell} z_{k_1}^{(\ell)} z_{k_1}^{(\ell)} z_{k_2}^{(\ell)} z_{k_2}^{(\ell)} + O(v^2) \right] \\
 & = \exp \left[-\frac{g^{(\ell), n_\ell}}{2} \sum_{j=1}^{m_\ell} z_j^{(\ell)} z_j^{(\ell)} + \frac{v^{(\ell)}}{8} \sum_{j_1, j_2=1}^{m_\ell} z_{j_1}^{(\ell)} z_{j_1}^{(\ell)} z_{j_2}^{(\ell)} z_{j_2}^{(\ell)} \right] \\
 & \times \left\{ 1 + \frac{(n_\ell - m_\ell)}{4} \frac{v^{(\ell)}}{g^{(\ell), n_\ell}} \left(\sum_{i=1}^{m_\ell} z_i^{(\ell)} z_i^{(\ell)} \right) \right. \\
 & \quad \left. + \frac{v^{(\ell)}}{8g_{(\ell), n_\ell}^2} [(n_\ell - m_\ell)^2 + 2(n_\ell - m_\ell)] + O(v^2) \right\}.
 \end{aligned} \tag{4.99}$$

最后, 把四次耦合产生的、正比于 $\sum_{i=1}^{m_\ell} z_i^{(\ell)} z_i^{(\ell)}$ 的修正重新求和回指数中, 忽略比例因子, 并与 m_ℓ 个神经元的作用量 (4.97) 比较, 得到

$$g_{(\ell), m_\ell} = g^{(\ell), n_\ell} - \frac{(n_\ell - m_\ell)}{2} \frac{v^{(\ell)}}{g^{(\ell), n_\ell}} + O(v^2), \tag{4.100}$$

这就是二次耦合的跑动方程.

观察耦合跑动并求出跑动方程 (4.100) 解的第二种方法, 是计算单输入度量 $G^{(\ell)} \equiv \mathbb{E} [z_i^{(\ell)} z_i^{(\ell)}]$, 并直接用 m_ℓ 神经元作用量 (4.97) 计算它. 前面已在 (4.47) 中用多输入的四次作用量完成过这一计算. 专门考虑单个输入、 m_ℓ 个神经元的作用量, 并显式写出二次耦合对神经元数的依赖, 得到

$$G^{(\ell)} = \left[\frac{1}{g_{(\ell), m_\ell}} + \frac{(m_\ell + 2)}{2} \frac{v^{(\ell)}}{g_{(\ell), m_\ell}^3} \right] + O(v^2). \tag{4.101}$$

按 $v^{(\ell)}$ 微扰展开并求解 $g_{(\ell), m_\ell}$, 得到

$$\frac{1}{g_{(\ell), m_\ell}} = G^{(\ell)} - \frac{(m_\ell + 2)}{2} \frac{V^{(\ell)}}{n_{\ell-1} G^{(\ell)}} + O\left(\frac{1}{n^2}\right), \tag{4.102}$$

其中还代入了

$$v^{(\ell)} = \frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^4} + O\left(\frac{1}{n^2}\right), \tag{4.103}$$

这里使用 (4.82) 与 (4.83) 把四次耦合关联到四点顶点, 并再次专门考虑单个输入. 现在很容易检查, 表达式 (4.102) 的确解出了跑动方程 (4.100).⁵²

这项替代推导的关键, 是认识到像 $G^{(\ell)}$ 这样不带任何神经元指标的可观测量, 不应依赖计算它时使用哪一种 m_ℓ 作用量. 换一种解释, 耦合的这种跑动意味着: 对于第 ℓ 层中不同的神经元数, 例如 m_ℓ 与 n_ℓ , 需要不同的二次耦合——这里分别是 $g_{(\ell), m_\ell}$ 与 $g_{(\ell), n_\ell}$ ——才能给出第 ℓ 层可观测量 (如 $G^{(\ell)}$) 的正确值. 如有疑问, 最稳妥的做法始终是用度量 $G^{(\ell)}$ 与四点顶点 $V^{(\ell)}$, 而不是用耦合来表示感兴趣的可观测量.

4.5 次领先修正

在有限宽度下, 所有相关子都会得到无穷级数的次领先修正. 具体而言, 控制二点相关子的度量与控制连通四点相关子的四点顶点, 具有如下形式的 $1/n$ 级数展开:

$$G_{\alpha_1\alpha_2}^{(\ell)} = G_{\alpha_1\alpha_2}^{\{0\}(\ell)} + \frac{1}{n_{\ell-1}} G_{\alpha_1\alpha_2}^{\{1\}(\ell)} + \frac{1}{n_{\ell-1}^2} G_{\alpha_1\alpha_2}^{\{2\}(\ell)} + O\left(\frac{1}{n^3}\right), \quad (4.104)$$

$$V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell)} = V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{\{0\}(\ell)} + \frac{1}{n_{\ell-1}} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{\{1\}(\ell)} + O\left(\frac{1}{n^2}\right). \quad (4.105)$$

到目前为止, 我们一直关注领先贡献 $G_{\alpha_1\alpha_2}^{\{0\}(\ell)}$ 与 $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{\{0\}(\ell)}$; 次领先修正同样可以系统地计算. 下面通过推导度量的次领先阶 (NLO) 修正 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 的递归来说明这一过程.

在继续之前先指出, 平均度量的领先贡献完全描述预激活量分布的无限宽极限, 因此赋予它记号

$$K_{\alpha_1\alpha_2}^{(\ell)} \equiv G_{\alpha_1\alpha_2}^{\{0\}(\ell)}, \quad (4.106)$$

并称之为**核**. 由于核刻画任意样本对之间的领先阶相关性, 它将成为后续各章研究的核心对象. 类似地, 把 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 称为 **NLO 度量**.

第一步是用 (4.104) 与 (4.105) 中精确到 $1/n$ 阶的相关子数据, 表示精确到 $1/n$ 阶的第 ℓ 层二次耦合 $g_{(\ell)}^{\beta_1\beta_2}$. 先回顾此前从四次作用量推导出的二点相关子表达式 (4.47), 将它对第 ℓ 层重写如下:

$$\begin{aligned} \mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell)} z_{i_2; \alpha_2}^{(\ell)} \right] &= \delta_{i_1 i_2} G_{\alpha_1 \alpha_2}^{(\ell)} \\ &= \delta_{i_1 i_2} \left[g_{\alpha_1 \alpha_2}^{(\ell)} + \frac{1}{2} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} v_{(\ell)}^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \left(n_\ell g_{\alpha_1 \beta_1}^{(\ell)} g_{\alpha_2 \beta_2}^{(\ell)} g_{\beta_3 \beta_4}^{(\ell)} + 2 g_{\alpha_1 \beta_1}^{(\ell)} g_{\alpha_2 \beta_3}^{(\ell)} g_{\beta_2 \beta_4}^{(\ell)} \right) \right] + O(v^2). \end{aligned} \quad (4.107)$$

提醒一下, $g_{\alpha_1 \alpha_2}^{(\ell)}$ 是二次耦合 $g_{(\ell)}^{\alpha_1 \alpha_2}$ 的矩阵逆. 把展开式 (4.104) 代入 (4.107), 再代入四次耦合 $v_{(\ell)} = V_{(\ell)}/n_{\ell-1}$ (4.82), 最后重新整理并求解精确到次领先阶的 $g_{\alpha_1 \alpha_2}^{(\ell)}$, 得到

$$g_{\alpha_1 \alpha_2}^{(\ell)} = K_{\alpha_1 \alpha_2}^{(\ell)} + \frac{1}{n_{\ell-1}} \left[G_{\alpha_1 \alpha_2}^{\{1\}(\ell)} - \sum_{\beta_1, \beta_2 \in \mathcal{D}} K_{(\ell)}^{\beta_1 \beta_2} \left(\frac{n_\ell}{2} V_{(\alpha_1 \alpha_2)(\beta_1 \beta_2)}^{(\ell)} + V_{(\alpha_1 \beta_1)(\alpha_2 \beta_2)}^{(\ell)} \right) \right] + O\left(\frac{1}{n^2}\right). \quad (4.108)$$

⁵²注意, 耦合 $g_{(\ell), m_\ell}$ 依赖 m_ℓ , 也依赖其他隐藏层宽度 $n_1, n_2, \dots, n_{\ell-1}$, 但不依赖当前层的总宽度 n_ℓ . 这意味着, 二次耦合 $g_{(\ell), m_\ell}$ 与第 ℓ 层实际上只有 m_ℓ 个神经元时所使用的耦合相同.

注意, 为得到上式, 已在次领先项中自洽地用 $K^{(\ell)}$ 替换 $g^{(\ell)}$; 这样又可以降低四点顶点的指标. 对表达式 (4.108) 求逆, 就能用相关子表示二次耦合的次领先修正:

$$g_{(\ell)}^{\beta_1\beta_2} - K_{(\ell)}^{\beta_1\beta_2} = \frac{1}{n_{\ell-1}} \sum_{\beta_3, \beta_4 \in \mathcal{D}} \left[-K_{(\ell)}^{\beta_1\beta_3} K_{(\ell)}^{\beta_2\beta_4} G_{\beta_3\beta_4}^{\{1\}(\ell)} + K_{\beta_3\beta_4}^{(\ell)} \left(\frac{n_{\ell}}{2} V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)} + V_{(\ell)}^{(\beta_1\beta_3)(\beta_2\beta_4)} \right) \right] + O\left(\frac{1}{n^2}\right). \quad (4.109)$$

注意, 这一修正中有一项按 $n_{\ell}/n_{\ell-1}$ 标度. 如上一节所述, 第 ℓ 层作用量的边缘化规则保证, 可以把这个量视为小量, 即 $n_{\ell}/n_{\ell-1} \ll 1$; 因此, $g_{\alpha_1\alpha_2}^{(\ell)} - K_{\alpha_1\alpha_2}^{(\ell)}$ 确实是二次耦合关于 $1/n$ 的次领先修正. 与这一说法一致, 马上就会看到, 在计算度量次领先修正 $G^{\{1\}(\ell)}$ 的递归时, 因子 n_{ℓ} 会抵消.

至此已经求出带 $1/n$ 修正的第 ℓ 层作用量, 接下来计算第 $(\ell+1)$ 层的二点相关子.⁵³ 这将使第 $(\ell+1)$ 层的二点相关子可以用第 ℓ 层的统计量表示, 并最终给出 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 的递归. 从第 $(\ell+1)$ 层中的展开式 (4.104) 出发, 代入二点相关子的表达式 (4.85), 得到

$$K_{\alpha_1\alpha_2}^{(\ell+1)} + \frac{1}{n_{\ell}} G_{\alpha_1\alpha_2}^{\{1\}(\ell+1)} + O\left(\frac{1}{n^2}\right) = G_{\alpha_1\alpha_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_{\ell}} \sum_{j=1}^{n_{\ell}} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right]. \quad (4.110)$$

因此, 需要精确到 $O(1/n)$ 阶的第 ℓ 层双激活期望; 此前已在表达式 (4.61) 中用第 ℓ 层耦合计算过它.

考察 (4.61) 可见, 次领先阶有两类贡献: 一类来自 (4.108) 中二次耦合 $g_{(\ell)}$ 的 $1/n$ 修正, 另一类来自四次耦合 $v_{(\ell)}$ 所导致的近高斯分布. 后一类贡献容易处理: 因为四次耦合已经受 $1/n$ 抑制, 只需在 (4.61) 的第二项中作替换 $g^{(\ell)} \rightarrow K^{(\ell)}$, 得到

$$\begin{aligned} & \frac{1}{8n_{\ell-1}} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)} \\ & \times \left[\left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \left(z_{\beta_3} z_{\beta_4} - K_{\beta_3\beta_4}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \right. \\ & \left. + 2n_{\ell} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} K_{\beta_3\beta_4}^{(\ell)} - 2 \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}} K_{\beta_1\beta_3}^{(\ell)} K_{\beta_2\beta_4}^{(\ell)} \right] + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (4.111)$$

但对前一类贡献, 需要把高斯项 $\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{g^{(\ell)}}$ 仔细分解为领先部分与次领先部分. 为此, 可以把关于 $g^{(\ell)}$ 的高斯期望换成关于领先核 $K^{(\ell)}$ 的高斯期望:

$$\begin{aligned} & \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{g^{(\ell)}} \\ & = \frac{\left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \exp \left[-\frac{1}{2} \sum_{\beta_1, \beta_2} \left(g_{(\ell)}^{\beta_1\beta_2} - K_{(\ell)}^{\beta_1\beta_2} \right) z_{\beta_1} z_{\beta_2} \right] \right\rangle_{K^{(\ell)}}}{\left\langle \exp \left[-\frac{1}{2} \sum_{\beta_1, \beta_2} \left(g_{(\ell)}^{\beta_1\beta_2} - K_{(\ell)}^{\beta_1\beta_2} \right) z_{\beta_1} z_{\beta_2} \right] \right\rangle_{K^{(\ell)}}} \\ & = \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}} - \frac{1}{2} \sum_{\beta_1, \beta_2} \left(g_{(\ell)}^{\beta_1\beta_2} - K_{(\ell)}^{\beta_1\beta_2} \right) \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (4.112)$$

⁵³ 四次耦合的 $1/n$ 贡献早已知道, 即关系 $v_{(\ell)} = V_{(\ell)}/n_{\ell-1}$.

把 (4.109) 代入 (4.112)，即可得到二次耦合变化所产生的次领先贡献：

$$\begin{aligned}
 & \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{g^{(\ell)}} \\
 &= \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}} + \frac{1}{2n_{\ell-1}} K_{(\ell)}^{\beta_1\beta_3} K_{(\ell)}^{\beta_2\beta_4} G_{\beta_3\beta_4}^{\{1\}(\ell)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \\
 & \quad - \frac{1}{n_{\ell-1}} \sum_{\beta_1, \dots, \beta_4} \left(\frac{n_{\ell}}{4} V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)} + \frac{1}{2} V_{(\ell)}^{(\beta_1\beta_3)(\beta_2\beta_4)} \right) K_{\beta_3\beta_4}^{(\ell)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \\
 & \quad + O\left(\frac{1}{n^2}\right).
 \end{aligned} \tag{4.113}$$

现在所有项都已算出。把 $\mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right]$ 的两个贡献 (4.111) 与 (4.113) 相加，再代入预激活量相关子的表达式 (4.110)。收集各项后，首先恢复领先贡献，即核的递归：

$$K_{\alpha_1\alpha_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}}, \tag{4.114}$$

并且如所承诺的那样，也得到 NLO 度量的递归：

$$\begin{aligned}
 & \frac{1}{n_{\ell}} G_{\alpha_1\alpha_2}^{\{1\}(\ell+1)} \\
 &= C_W^{(\ell+1)} \frac{1}{n_{\ell-1}} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} \left[\frac{1}{2} K_{(\ell)}^{\beta_1\beta_3} K_{(\ell)}^{\beta_2\beta_4} G_{\beta_3\beta_4}^{\{1\}(\ell)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \right. \\
 & \quad + \frac{1}{8} V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \left(z_{\beta_3} z_{\beta_4} - K_{\beta_3\beta_4}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \\
 & \quad \left. + \frac{1}{4} V_{(\ell)}^{(\beta_1\beta_3)(\beta_2\beta_4)} K_{\beta_3\beta_4}^{(\ell)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(-2z_{\beta_1} z_{\beta_2} + K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \right].
 \end{aligned} \tag{4.115}$$

在个人笔记或本书页边完整写出这项计算时，可以明确看到，不参与期望 $\mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right]$ 的 $n_{\ell} - 1$ 个旁观神经元所产生的贡献恰好抵消；第 ℓ 层作用量的边缘化规则正要求如此。确实，方程 (4.115) 右边方括号内的每一项显然都是一阶量。

这个过程可以系统地推进到更高阶。正如计算 NLO 度量 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 需要领先四次耦合一样，计算四点顶点的次领先修正 $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{\{1\}(\ell)}$ ，以及计算二点相关子的 $1/n^2$ 阶修正 $G_{\alpha_1\alpha_2}^{\{2\}(\ell)}$ ，都会涉及领先六次耦合。这种六次耦合在作用量中出现在 $1/n^2$ 阶，并对连通六点函数作出贡献；后者同样按 $O(1/n^2)$ 消失。⁵⁴

4.6 RG 流与 RG 流

过去五节充满了方程、代数和积分，现在不妨稍作停顿，回顾并汇总主要结果。

本章的目标，是用一个具有数据依赖耦合的有效作用量 (effective action)，表示给定第 ℓ 层中预激活量的边缘分布 $p(z^{(\ell)} | \mathcal{D})$ 。这些耦合逐层改变——或者说发生**跑动**

⁵⁴对于熟悉场论的读者，作用量中耦合的领先部分是相关子的树级贡献。它们应与本节讨论的二点相关子的次领先修正相区别；后者既包含四次相互作用产生的圈级贡献，也包含裸二次耦合的 NLO 修正所产生的树级贡献。

——而跑动由递归决定，递归又决定预激活量分布如何随深度变化。等价地说，这些递归告诉我们预激活量的相关子如何随层演化。在这种语言下，从第一层中的独立神经元（第 4.1 节）出发，我们已经看到神经元间的相互作用如何在第二层被诱导出来（第 4.2 节），继而在更深层中得到放大（第 4.3 节）。

具体而言，下面概括宽网络展开领先阶上有限宽网络的行为。用核 $K_{\alpha_1\alpha_2}^{(\ell)}$ 表示预激活量的二点相关子：

$$\mathbb{E} \left[z_{i_1;\alpha_1}^{(\ell)} z_{i_2;\alpha_2}^{(\ell)} \right] = \delta_{i_1 i_2} G_{\alpha_1\alpha_2}^{(\ell)} = \delta_{i_1 i_2} \left[K_{\alpha_1\alpha_2}^{(\ell)} + O\left(\frac{1}{n}\right) \right], \quad (4.116)$$

并用四点顶点（four-point vertex） $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell)}$ 表示连通四点相关子：

$$\begin{aligned} & \mathbb{E} \left[z_{i_1;\alpha_1}^{(\ell)} z_{i_2;\alpha_2}^{(\ell)} z_{i_3;\alpha_3}^{(\ell)} z_{i_4;\alpha_4}^{(\ell)} \right] \Big|_{\text{connected}} \\ &= \frac{1}{n_{\ell-1}} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell)} + \delta_{i_1 i_3} \delta_{i_2 i_4} V_{(\alpha_1\alpha_3)(\alpha_2\alpha_4)}^{(\ell)} + \delta_{i_1 i_4} \delta_{i_2 i_3} V_{(\alpha_1\alpha_4)(\alpha_2\alpha_3)}^{(\ell)} \right], \end{aligned} \quad (4.117)$$

这些相关子的跑动由如下递归给出：

$$K_{\alpha_1\alpha_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}}, \quad (4.118)$$

$$\begin{aligned} V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell+1)} &= \left(C_W^{(\ell+1)} \right)^2 \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{K^{(\ell)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{K^{(\ell)}} \right], \\ &+ \frac{1}{4} \left(C_W^{(\ell+1)} \right)^2 \frac{n_\ell}{n_{\ell-1}} \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} V_{(\ell)}^{(\beta_1\beta_2)(\beta_3\beta_4)} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \left(z_{\beta_1} z_{\beta_2} - K_{\beta_1\beta_2}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} \\ &\quad \times \left\langle \sigma_{\alpha_3} \sigma_{\alpha_4} \left(z_{\beta_3} z_{\beta_4} - K_{\beta_3\beta_4}^{(\ell)} \right) \right\rangle_{K^{(\ell)}} + O\left(\frac{1}{n}\right), \end{aligned} \quad (4.119)$$

其中，四点顶点的指标由逆度量 $G_{(\ell)}$ 升起：

$$\begin{aligned} V_{(\ell)}^{(\alpha_1\alpha_2)(\alpha_3\alpha_4)} &\equiv \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} G_{(\ell)}^{\alpha_1\beta_1} G_{(\ell)}^{\alpha_2\beta_2} G_{(\ell)}^{\alpha_3\beta_3} G_{(\ell)}^{\alpha_4\beta_4} V_{(\beta_1\beta_2)(\beta_3\beta_4)}^{(\ell)} \\ &= \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} K_{(\ell)}^{\alpha_1\beta_1} K_{(\ell)}^{\alpha_2\beta_2} K_{(\ell)}^{\alpha_3\beta_3} K_{(\ell)}^{\alpha_4\beta_4} V_{(\beta_1\beta_2)(\beta_3\beta_4)}^{(\ell)} + O\left(\frac{1}{n}\right). \end{aligned} \quad (4.120)$$

这些递归支配预激活量统计量如何随深度流动。

这种流动很容易让人联想到下面这幅关于神经网络如何工作的启发式图景：给定一个输入，例如一幅猫的图像，最初几层从像素中识别低层特征——例如低强度与高强度区域之间的边缘；中间层再把这些低层特征组装成中层特征——例如皮毛的纹理与图案；更深的层进一步把它们聚合成高层表征——例如尾巴和耳朵；最后一层则将它们结合起来，估计原始像素表示一只猫的概率。的确，有些研究支持训练后网络中特征表征按层级排列的图景 [34].⁵⁵ 这种排列的可取性凸显了深度在深度学习中的作用与重要性。

讨论这幅启发式图景时使用的若干术语，其实可以给出更精确的定义。例如，网络中的每个神经元——不仅包括输出层中的神经元，也包括隐藏层中的神经元——都是输

⁵⁵有人指出，即使未经训练的网络也具有可以充当某类滤波器的特征，从而实际上能够在未训练网络中进行初级边缘检测。相关思想见 [35]。

入的标量函数，称为特征 (feature)。给定一层的神经元可以组织成输入的向量值函数，我们称之为表征 (representation)。⁵⁶ 用这些概念来说，我们的形式体系追踪表征从一层到下一层的变换。我们把这种表征流称为表征群流 (representation group flow)，简称 **RG 流**。⁵⁷ RG 流由反复边缘化浅层中的细粒度特征而诱导，最终给出输出层中的粗粒化表征。我们的 RG 流概念使上述启发式图景变得具体。

这种粗粒化模式在理论物理学中有一个对应概念，称为重整化群流 (renormalization group flow)，也简称 **RG 流**。在这种情况下，RG 流通过反复边缘化系统中微观的细粒度自由度而产生，从而得到用宏观粗粒化变量表述的系统有效理论。类似地，控制这些有效自由度相互作用的物理耦合，会随探测它们的长度尺度而跑动——例如，在不同尺度下探测电子时，其有效电荷会发生变化。与描述网络表征之跑动耦合的递归方程相似，人们可以推导出支配物理耦合随尺度跑动的微分方程；历史上，这些方程称为 beta 函数。⁵⁸

为了把这两种 RG 流之间的联系说得十分清楚，我们简要看看它在物理场论中如何实现。在这种情形下，自由度由场 $\phi(x)$ 表示，它随时空坐标 x 可以取不同的值。首先，把 $\phi(x)$ 分成由高频模组成的细粒度变量 ϕ^+ 和由低频模组成的粗粒度变量 ϕ^- ，使得场分解为 $\phi(x) = \phi^+(x) + \phi^-(x)$ 。完整分布由完整作用量控制：

$$S_{\text{full}}(\phi) = S(\phi^+) + S(\phi^-) + S_I(\phi^+, \phi^-), \quad (4.121)$$

其中最后一项尤其描述了这两组模之间的相互作用。

现在，如果我们只关心宏观尺度下仅依赖粗粒度模 ϕ^- 的可观测量——而实验通常关注的正是这种长程尺度——那么这种完整描述就过于繁复，难以有效描述实验结果。

⁵⁶在研究监督学习（第 7 章）时，我们主要关心如何通过基于梯度的训练来学习输出层中的表征 $z^{(L)}$ ；但理解隐藏层中的表征如何学习也很重要（第 11 章）。隐藏层表征不仅是确定输出端粗粒化表征的必要组成部分，而且在深度学习的一些应用中，其本身还可作为其他学习任务的输入。这种情形在无监督学习中十分常见，例如自然语言处理任务中的词嵌入。在这些场景中，嵌入——即完整句子这一更大语境中某个输入词的表征——通常不仅取自最后一层，而是取自最后若干层的拼接。例如见 [36]。

⁵⁷对于表征群流这一名称，我们必须致歉两次：(i) 它与数学中的群表示论概念近得容易混淆；(ii) 从技术上说，这种流是一个半群，而不是群。（群论和半群论都研究变换，但群要求逆元，半群则不要求；而这种流没有逆。）这不过是重复了物理学上的一个历史错误，下面的脚注还会进一步说明。

⁵⁸物理学中重整化的简史。

重整化最初发展于 20 世纪 30 与 40 年代，用来处理困扰量子场论实验可观测量计算的发散——即无穷大。起初，人们只是把这些无穷大减掉——如果你愿意，也可以说是把它们扫到地毯下面——得到的答案尽管采用了这类手法，却与实验吻合得极好。整个局面被视为一种尴尬，几乎导致这一理论被放弃。

这些发散的产生，本质上是因为没有恰当地考虑耦合可能依赖尺度。跑动耦合的思想最早由 Gell-Mann 与 Low 于 1954 年提出 [37]，但直到 Wilson 在 1971 年发展出现代 RG 流概念 [38, 39]，重整化才得到完整的概念化；这一概念既为统计物理中的临界现象提供了理论解释，也为理解量子场论中的发散奠定了坚实基础。

讲到这里，所有 RG 历史叙述似乎都有义务提及：重整化群并不是群，而是半群。（这个错误源自 Stueckelberg 与 Petermann 的一篇早期论文，其中把这种流称为“归一化群” [40]。）从数学上说，这是因为不存在逆元；从联合分布中边缘化掉变量会删除信息，因而无法撤销。特别地，两个不同的联合分布经边缘化后，有时可以流向同一个分布。直观地说，这是因为这些流从细粒度描述走向粗粒度描述。（这种汇聚流引出了普适性概念；第 5 章将在神经网络语境中解释：具有不同激活函数的网络如何在 RG 下流向相同的边缘分布。）

显然，物理学中的 RG 流是一个极其丰富的主题。若有兴趣深入学习，我们推荐 [41, 42]。

为了得到只用这些粗粒度变量 ϕ^- 表述的有效描述，可以把细粒度变量 ϕ^+ 积分掉（即对其作边缘化）：

$$e^{-S_{\text{eff}}(\phi^-)} = \int d\phi^+ e^{-S_{\text{full}}(\phi)}, \quad (4.122)$$

由此得到**有效作用量** $S_{\text{eff}}(\phi^-)$ ，它为实验所关心的可观测量提供了一个有效理论。实际上，这种边缘化逐尺度进行：把场从微观模 $\phi^{(1)}$ 一直分解到宏观模 $\phi^{(L)} = \phi^-$ ，即 $\phi = \phi^{(1)} + \dots + \phi^{(L)}$ ，再依次积分掉变量 $\phi^{(1)}, \dots, \phi^{(L-1)}$ 。追踪有效作用量中的耦合在这一边缘化过程中的流动，就得到前述 beta 函数；把这些微分方程求解到所关心的尺度，便得到该尺度下可观测量的有效描述。

这恰好就是本章一直在为神经网络所做的事。完整场 ϕ 类似于所有预激活量的集合 $\{z^{(1)}, \dots, z^{(L)}\}$ 。它们的分布由预激活量的完整联合分布控制：

$$p(z^{(1)}, \dots, z^{(L)} | \mathcal{D}) = p(z^{(L)} | z^{(L-1)}) \dots p(z^{(2)} | z^{(1)}) p(z^{(1)} | \mathcal{D}), \quad (4.123)$$

其完整作用量为

$$S_{\text{full}}(z^{(1)}, \dots, z^{(L)}) \equiv \sum_{\ell=1}^L S_{\text{M}}(z^{(\ell)}) + \sum_{\ell=1}^{L-1} S_{\text{I}}(z^{(\ell+1)} | z^{(\ell)}). \quad (4.124)$$

这里，完整作用量分解为变量 $z^{(\ell)}$ 的平均二次作用量

$$S_{\text{M}}(z^{(\ell)}) = \frac{1}{2} \sum_{i=1}^{n_{\ell}} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(\ell)}^{\alpha_1 \alpha_2} z_{i; \alpha_1}^{(\ell)} z_{i; \alpha_2}^{(\ell)}, \quad (4.125)$$

其中使用平均度量 $G^{(\ell)}$ ，见 (4.72)；以及相邻层间的相互作用

$$S_{\text{I}}(z^{(\ell+1)} | z^{(\ell)}) = \frac{1}{2} \sum_{i=1}^{n_{\ell+1}} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} \left[\hat{G}_{(\ell+1)}^{\alpha_1 \alpha_2}(z^{(\ell)}) - G_{(\ell+1)}^{\alpha_1 \alpha_2} \right] z_{i; \alpha_1}^{(\ell+1)} z_{i; \alpha_2}^{(\ell+1)}. \quad (4.126)$$

这里特别强调，随机度量 $\hat{G}_{\alpha_1 \alpha_2}^{(\ell+1)}$ 是 $z^{(\ell)}$ 的函数，而由此诱导出的 $z^{(\ell)}$ 与 $z^{(\ell+1)}$ 的耦合正是层间相互作用的来源。

现在，如果我们只关心仅依赖网络输出的可观测量——这当然包括一个非常重要的可观测量……输出本身！——那么这种完整描述就过于繁复。为了得到输出 $z^{(L)}$ 分布的有效（即有用的）描述，可以对所有特征 $\{z^{(1)}, \dots, z^{(L-1)}\}$ 作边缘化：

$$e^{-S_{\text{eff}}(z^{(L)})} = \int \left[\prod_{\ell=1}^{L-1} dz^{(\ell)} \right] e^{-S_{\text{full}}(z^{(1)}, \dots, z^{(L)})}, \quad (4.127)$$

这与在 (4.122) 中积分掉细粒度模 ϕ^+ 、从而得到用粗粒度模 ϕ^- 表述的有效描述完全相同。而且，与场论例子一样，我们没有一次性完成这种边缘化，而是逐层依次积分掉预激活量。这就得到递归关系 (4.118) 与 (4.119)；把这些递归关系求解到所关心的深度，便得到该深度下神经网络输出的有效描述。⁵⁹

⁵⁹给物理学家的注：网络中从输入到输出的流，是从紫外到红外的流。

最后这句话暗示了一种微妙却有趣的视角转换，下面详细说明。到目前为止，本章都隐含地假定网络深度 L 固定，并描述输入 x 在中间层传播时预激活量分布如何变化，从而得到相关子和耦合从第 ℓ 层演化到第 $\ell + 1$ 层的递归关系，其中 $\ell = 0, \dots, L - 1$ 。然而，也完全可以把所得递归方程看作支配输出分布在网络总深度从 L 变为 $L + 1$ 时的变化。⁶⁰ 换言之，这些递归关系通过比较分布 $p(z^{(L)}|\mathcal{D})$ 与 $p(z^{(L+1)}|\mathcal{D})$ ，描述向神经网络中再添加一层的效果。

从这一视角出发，我们的 RG 流可以直面深度学习中“深度”的作用。例如，随着网络变深，神经元间的相互作用——编码在四点顶点 $V^{(\ell)}$ 等有限宽修正中——究竟会增强还是衰减？用 RG 流的语言说，随流动增长的耦合称为相关的（relevant），随流动缩小的则称为无关的（irrelevant）。⁶¹ 这些名称暗示了相互作用对于有效理论是否重要，因此我们也采用同样的术语。于是，为了探究深度对神经元—神经元相互作用的影响，我们只需问四点顶点 $V^{(\ell)}$ 是相关的还是无关的。

这个问题对深度学习具有重要影响。如果所有有限宽耦合都是无关的，那么有限宽网络在 RG 流下就会渐近趋于无限宽架构。这将意味着网络越深，其行为就越像无限宽模型，因而深度学习其实是在研究这些简单得多的高斯模型。幸运的是，我们很快会发现这些耦合是相关的，这使我们的研究更丰富，尽管也更复杂。下一章将说明，有限网络越深，偏离其无限宽对应物就越远。这会带来重要的实际后果：既影响监督训练中不同实例之间涨落的控制，也使网络能够学习输入的非平凡表征（第 11 章）。

下一章将显式求解 (4.118) 与 (4.119) 等递归方程，以探究这些“相关”问题。

⁶⁰严格地说，输出维数 n_{out} 固定。因而，当深度从 L 变为 $L + 1$ 时，可以设想保持 $\ell < L$ 各层的宽度不变，插入一个宽度 $n_L \sim n \gg 1$ 的新第 L 层，再令最终的第 $L + 1$ 层具有宽度 n_{out} 。

⁶¹既不增长也不缩小的耦合称为边缘的（marginal）。

第 5 章

初始化时预激活量的有效理论

我们相信这一研究领域极其重要而丰富，但我们预计，它若要发展，就需要其较为浪漫的拥护者历来不愿进行的那种批判性分析……

Minsky 与 Papert，载于 1988 年增订版《感知机》的序言 [43].

深度学习最关键的定义性特征，是把组件逐层堆叠起来，形成一个深层神经网络架构。尽管经验上偏爱更深的网络，但深度为何有利于学习，远非显然。当每层神经元数固定时，深度意味着参数多得多，而在深度学习中，更多参数往往带来更好的性能。但增加参数还有其它办法。例如，为什么不只用一个非常宽的隐藏层？事实上，在严格无限宽极限下，这样的单隐藏层模型与任何更深的 MLP 拥有相同数量的参数：无穷多个。

思考深度效应的正确方式，不是仅仅计算模型参数的数量，而是询问：向 MLP 再增加一层会发生什么？第 4 章已经建立了一套形式体系，通过所关心可观测量的递归来精确回答这个问题，使我们能够计算增加一层后初始网络输出的分布如何变化。因而现在需要一种工具，能从这些递归中有效提取显式的深度依赖性。

以第 4 章建立的有效理论形式体系为基础，本章将把第 3 章所作的临界性与涨落分析，推广到具有任意非线性激活函数的 MLP。上一章在宽网络区间 ($n \gg 1$) 中发现的简化启发我们，现在还要在大深度极限 ($L \gg 1$) 中寻求进一步简化。⁶² 我们先分析每层神经元数为无穷的极限，再退出这一极限，考虑宽度与深度都很大但有限的网络。最终将在这些渐近极限下得到预激活量二点与四点相关子的显式表达式。⁶³

这将使我们能够回答：初始化时，输入信号穿过深度神经网络的许多层时会发生什么（第 5.1 节）。我们将认识到，初始化超参数的一阶数值——即偏置方差 $C_b^{(\ell)}$ 与重标度权重方差 $C_w^{(\ell)}$ ——会对可观测量的行为产生显著的定性影响，正如第 3 章对深度线性网络所见。特别地，我们将解释为何网络越深，神经网络行为对这些初始化超参数就越敏感。⁶⁴

⁶²结合第 3.4 节的讨论，这意味着我们先取大宽度极限，再考察大深度极限。

⁶³尽管这些解具有渐近性质，但要指出的是，其中许多工具原本是为研究强相互作用而发展的；在这种研究中，实际取值为 3 的参数会被视为无穷大。因而有时甚至可以认为 $3 \sim \infty$ ，因为 $1/3 \ll 1$ 可以充当微扰参数 [44].

⁶⁴这项分析的初始部分最早由一系列论文 [45–47] 用另一套技术完成；在无限宽极限下，那套技术最终

这样的调谐会把网络带到临界性；这个术语借自统计物理，用来描述自相似系统。为此，我们给出一般方案：针对给定的激活函数与网络架构，把初始化超参数调到其临界值（第 5.2 节与第 5.3 节）。在此过程中，我们也会找出一些不允许临界性的激活函数。还会看到，某些激活函数在调到临界性时表现得非常相似，这揭示了它们与统计物理中普适性概念的重要联系。

接着，在临界性处研究有限宽修正，会引出本章的一个主要结果：由网络深度与网络宽度之比 L/n 给出的涌现尺度（第 5.4 节）。这个深宽比最终充当有效理论的截断，既控制有效理论的适用范围，也决定无限宽描述之有限宽修正的强度与重要性。在谱的一端，网络越矮胖，其行为就越接近无限宽对应物。在另一端，网络越瘦高，由神经元间相互作用造成的非高斯涨落就越占主导。总体而言，这推广了第 3.3 节对深度线性网络的涨落分析。

最后，本章将讨论并解决对 ReLU 等非光滑激活函数作临界性分析时出现的一处微妙问题（第 5.5 节）。

5.1 核的临界性分析

本章的大部分内容，旨在把第 3 章讨论的临界性概念推广到具有一般激活函数 $\sigma(z)$ 的深度 MLP。出发点是上一章推导的核递归

$$K_{\alpha\beta}^{(\ell+1)} = C_b + C_W \langle \sigma_\alpha \sigma_\beta \rangle_{K^{(\ell)}}. \quad (5.1)$$

回顾一下，由 (4.116) 定义的核 $K_{\alpha\beta}^{(\ell)}$ ，是平均度量 $G_{\alpha\beta}^{(\ell)}$ 的无限宽极限。为了限制不同超参数的数量，这里令偏置方差 $C_b^{(\ell)} = C_b$ 与重标度权重方差 $C_W^{(\ell)} = C_W$ 不依赖于层。这一递归的初始条件由第一层核给出：

$$K_{\alpha\beta}^{(1)} = C_b + C_W \left(\frac{1}{n_0} \sum_{i=1}^{n_0} x_{i;\alpha} x_{i;\beta} \right), \quad (5.2)$$

它由输入的内积 $\sum_{i=1}^{n_0} x_{i;\alpha} x_{i;\beta}$ 决定。我们的目标是分析核如何随层变化；将会看到，仅在核层面作这种分析，就足以在 $1/\text{宽度}$ 的领先阶上确定临界初始化超参数。

对于深度线性网络，激活函数关于核的高斯期望就是核本身，即 $\langle \sigma_\alpha \sigma_\beta \rangle_{K^{(\ell)}} = \langle z_\alpha z_\beta \rangle_{K^{(\ell)}} = K_{\alpha\beta}^{(\ell)}$ ，因此递归方程足够简单，可以求得完整解。然而，一旦离开 linear 激活函数的范围，核递归就会出现两个需要谨慎处理的新困难：(i) 期望值 $\langle \sigma_\alpha \sigma_\beta \rangle_{K^{(\ell)}}$ 将是核的非线性函数；(ii) 对两个不同输入 $\alpha \neq \beta$ ，递归会把非对角分量 $K_{\alpha\beta}^{(\ell)}$ 与对角分量 $K_{\alpha\alpha}^{(\ell)}$ 、 $K_{\beta\beta}^{(\ell)}$ 混合起来。

用二次激活函数 $\sigma(z) = z^2$ 来说明这一点。如今我们应已习惯，计算 (5.1) 需要两对 Wick 缩并，从而得到

$$\begin{aligned} K_{\alpha\beta}^{(\ell+1)} &= C_b + C_W \langle z_\alpha^2 z_\beta^2 \rangle_{K^{(\ell)}} \\ &= C_b + C_W \left(K_{\alpha\alpha}^{(\ell)} K_{\beta\beta}^{(\ell)} + 2 K_{\alpha\beta}^{(\ell)} K_{\alpha\beta}^{(\ell)} \right). \end{aligned} \quad (5.3)$$

与我们的等价。在此基础上，我们将依照临界性原理找出两个非常一般的条件，用来确定初始化超参数正确的一阶数值。第 10.3 节还会看到，要求充分训练后的网络具有良好泛化能力，也能说明为何需要这些条件。

因此，与深度线性网络不同，对于二次激活函数， $K_{\alpha\beta}^{(\ell+1)}$ 不仅依赖于 $K_{\alpha\beta}^{(\ell)}$ ，还依赖于 $K_{\alpha\alpha}^{(\ell)}$ 与 $K_{\beta\beta}^{(\ell)}$ ；当 $\alpha \neq \beta$ 时，需要求解三个耦合的非线性递归方程。这种混合是非线性激活函数的一般性质。

对实践者而言，这是好消息：核的非对角元素与网络的泛化能力有关。对深度线性网络来说，缺乏由非线性引起的混合，暗示一种归纳偏置，限制了这类网络为样本对形成非平凡相关性的能力。混合在实践中是益处，在理论上却是障碍，尽管并非不可克服。由于核递归至多混合两个输入，只需分析单个输入与两个不同输入的情形。下面依次进行这两项分析，以推导临界性的一般条件。

单个输入

核的每个对角分量都可以独立地自洽求解。具体而言，用 $\alpha = 0$ 标记单个输入，则

$$\begin{aligned} K_{00}^{(\ell+1)} &= C_b + C_W \langle \sigma(z_0) \sigma(z_0) \rangle_{K^{(\ell)}} \\ &= C_b + C_W g(K_{00}^{(\ell)}) . \end{aligned} \quad (5.4)$$

这里引入辅助函数

$$g(K) \equiv \langle \sigma(z) \sigma(z) \rangle_K \equiv \frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} \sigma(z) \sigma(z) , \quad (5.5)$$

以强调期望 $\langle \sigma(z_0) \sigma(z_0) \rangle_{K^{(\ell)}}$ 仅是核的单个分量 $K_{00}^{(\ell)}$ 的函数。首先把注意力集中在单输入核上，就能先处理非线性，再面对核分量的混合。

特别地，单输入递归 (5.4) 实际上告诉我们，输入的预激活量平均大小

$$K_{00}^{(\ell)} = \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;0}^{(\ell)} \right)^2 \right] , \quad (5.6)$$

如何随层 ℓ 变化，而递归的初始条件由 (5.2) 给定。出于第 3.2 节讨论过的同样理由，我们希望核 $K_{00}^{(\ell)}$ 既不指数爆炸，也不指数消失。然而，这类指数行为是一般情形；因此，对初始化超参数 (C_b, C_W) 的大多数选择，核要么朝无穷远处的平凡固定点指数爆炸，要么指数塌缩到有限值 K_{00}^* 处的平凡固定点。所以，我们的第一个临界性条件，是缓解单个输入的核爆炸或塌缩问题。

分析单输入核递归 (5.4) 这类非线性递归，有一种古老技术：在固定点附近线性化。也就是说，先找出递归的一个固定点，即满足

$$K_{00}^* = C_b + C_W g(K_{00}^*) , \quad (5.7)$$

的值 K_{00}^* ，再在其附近把核展开为

$$K_{00}^{(\ell)} = K_{00}^* + \Delta K_{00}^{(\ell)} . \quad (5.8)$$

把这一展开代入单输入递归 (5.4)，得到线性化递归

$$\Delta K_{00}^{(\ell+1)} = \chi_{||}(K_{00}^*) \Delta K_{00}^{(\ell)} + O(\Delta^2) , \quad (5.9)$$

其中引入平行易感率 (parallel susceptibility)

$$\begin{aligned}\chi_{\parallel}(K) &\equiv C_W g'(K) \\ &= C_W \frac{d}{dK} \left[\frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} \sigma(z) \sigma(z) \right], \\ &= \frac{C_W}{2K^2} \langle \sigma(z) \sigma(z) (z^2 - K) \rangle_K.\end{aligned}\tag{5.10}$$

易感率 $\chi_{\parallel}(K)$ 刻画核对固定点附近扰动的敏感程度, 名称由此而来: 根据 $\chi_{\parallel}(K_{00}^*) > 1$ 还是 $\chi_{\parallel}(K_{00}^*) < 1$, 核值会以指数方式离开固定点值膨胀, 或向固定点值收缩. (“平行”这一标记将在本节最后解释.)

因此, 为了在线性阶缓解单个输入的这种核爆炸与消失问题, 必须调谐初始化超参数 (C_b, C_W) , 使得

$$\chi_{\parallel}(K_{00}^*) = 1,\tag{5.11}$$

其中固定点值 K_{00}^* 由固定点方程 (5.7) 隐式定义. 稍后将详细说明, 依激活函数的选择不同, 临界性可以通过三种方式出现:

1. 正如在深度线性网络中所见, 单输入核可精确保持为 $K_{00}^{(\ell)} = K_{00}^{(1)} = C_b + C_W (\sum_i x_{i;0} x_{i;0} / n_0)$, 由此得到一条以输入范数 $\sum_i x_{i;0} x_{i;0}$ 参数化的固定点线. 第 5.2 节将看到, 对尺度不变激活函数, 由于 (5.9) 中不存在高阶修正 $O(\Delta^{p>1})$, 会出现这种情形.
2. 对所有输入范数, 核都可以缓慢衰减到固定点 $K_{00}^* = 0$, 其幂律为 $K_{00}^{(\ell)} \sim 1/\ell^q$, 其中 $0 < q \leq 1$. 第 5.3.3 节将看到, 对包括 $\tanh$ 与 $\sin$ 在内的一类激活函数, 由于 (5.9) 中存在 $O(\Delta^{p>1})$ 修正, 会出现这种情形.
3. 临界性可以表现为趋向非零固定点值 $K_{00}^* \neq 0$ 的幂律衰减. 第 5.3.4 节将看到, SWISH 与 GELU 激活函数会出现这种情形.

在所有这些情形中, 当初始化超参数被调到临界性时, 我们称 $K_{00}^* = K_{00}^*(C_b^{\text{critical}}, C_W^{\text{critical}})$ 为非平凡固定点 (nontrivial fixed point), 以区别于一般超参数对应的平凡固定点; 在后者附近, 扰动呈指数行为.

两个输入

现在给定两个不同输入, 用样本指标 $\alpha = \pm$ 标记它们. 对这样一对输入, 需要考虑三个不同的核分量: $K_{++}^{(\ell)}$ 、 $K_{--}^{(\ell)}$ 和 $K_{+-}^{(\ell)} = K_{-+}^{(\ell)}$. 单输入分析可以直接确定对角分量 $K_{++}^{(\ell)}$ 与 $K_{--}^{(\ell)}$ 的层依赖性; 因此, 在已知对角部分之解的情况下, 要完成分析还需提取非对角分量 $K_{+-}^{(\ell)}$ 的层依赖性. 这项分析将给出第二个临界性条件; 它与 (5.11) 一起, 就能为给定激活函数确定临界初始化超参数 $(C_b, C_W)^{\text{critical}}$.

最终, 我们将在两个输入完全重合的退化极限附近线性化, 即 $x_{i;+}, x_{i;-} \rightarrow x_{i;0}$. 在这个极限下, 两个输入的所有配对方式都相同, 所以完整核矩阵的全分量必取同一个值, 即 $K_{++}^{(\ell)}, K_{--}^{(\ell)}, K_{+-}^{(\ell)} \rightarrow K_{00}^{(\ell)}$. 因而, 每个递归都退化为同一个单输入递归 (5.4), 而

我们知道它具有固定点值 K_{00}^* . 这意味着重合极限解

$$\begin{pmatrix} K_{++}^{(\ell)} & K_{+-}^{(\ell)} \\ K_{-+}^{(\ell)} & K_{--}^{(\ell)} \end{pmatrix} = \begin{pmatrix} K_{00}^* & K_{00}^* \\ K_{00}^* & K_{00}^* \end{pmatrix} = K_{00}^* \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad (5.12)$$

也必定是双输入完整核递归的固定点.

为了理解完整核矩阵如何趋近这个退化固定点, 需要考虑三种不同的扰动. 第一种对应单输入分析中出现的扰动 $\Delta K_{00}^{(\ell)}$, 它控制核的四个分量之平均值如何趋近固定点值 K_{00}^* . 接着, 退出重合极限时, 单个输入分裂为两个不同输入: $x_{i;0} \rightarrow x_{i;+}, x_{i;-}$. 可以设想把这两个输入分开, 使它们具有不同大小, 即 $\sum_i x_{i;+}^2 \neq \sum_i x_{i;-}^2$, 并追踪这种差异在网络中的期望演化:

$$R^{(\ell)} \equiv \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;+}^{(\ell)} \right)^2 \right] - \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;-}^{(\ell)} \right)^2 \right] = K_{++}^{(\ell)} - K_{--}^{(\ell)}. \quad (5.13)$$

这种扰动实际上仍包含在单输入分析中, 因为对角分量 $K_{++}^{(\ell)}$ 与 $K_{--}^{(\ell)}$ 的演化彼此独立, 而它们趋向固定点的过程仅由单输入递归控制.

最后, 与其考虑平方之差, 不如考虑差的平方:

$$D^{(\ell)} \equiv \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;+}^{(\ell)} - z_{i;-}^{(\ell)} \right)^2 \right] = K_{++}^{(\ell)} + K_{--}^{(\ell)} - 2K_{+-}^{(\ell)}. \quad (5.14)$$

右边的表达式来自展开二项式, 再使用核分量的定义. 这个量度量两个输入经过网络的 ℓ 层之后其差的大小; 即使输入本身大小相同, 即 $\sum_i x_{i;+}^2 = \sum_i x_{i;-}^2$, 它也可以不为零. 重要的是, 距离度量 $D^{(\ell)}$ 依赖核的非对角分量 $K_{+-}^{(\ell)}$, 所以分析这一扰动应当给出新信息. 将会看到, 第三种扰动 $D^{(\ell)}$ 趋近 $D^{(\ell)} = 0$ 的重合固定点的方式, 将给出第二个临界性条件. 它与单输入临界性条件 (5.11) 一起, 足以完全确定临界初始化超参数.

现在把上述讨论转化为数学. 为此, 把完整核矩阵投影到如下基底会很方便:

$$K_{\alpha_1 \alpha_2}^{(\ell)} = \begin{pmatrix} K_{++}^{(\ell)} & K_{+-}^{(\ell)} \\ K_{-+}^{(\ell)} & K_{--}^{(\ell)} \end{pmatrix} = K_{[0]}^{(\ell)} \gamma_{\alpha_1 \alpha_2}^{[0]} + K_{[1]}^{(\ell)} \gamma_{\alpha_1 \alpha_2}^{[1]} + K_{[2]}^{(\ell)} \gamma_{\alpha_1 \alpha_2}^{[2]}, \quad (5.15)$$

其中引入对称矩阵

$$\gamma_{\alpha_1 \alpha_2}^{[0]} \equiv \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \gamma_{\alpha_1 \alpha_2}^{[1]} \equiv \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}, \quad \gamma_{\alpha_1 \alpha_2}^{[2]} \equiv \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}. \quad (5.16)$$

在这一基底中, 核的分量为

$$K_{[0]}^{(\ell)} = \frac{1}{4} \left[K_{++}^{(\ell)} + K_{--}^{(\ell)} + 2K_{+-}^{(\ell)} \right] = \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(\frac{z_{i;+}^{(\ell)} + z_{i;-}^{(\ell)}}{2} \right)^2 \right], \quad (5.17)$$

$$K_{[1]}^{(\ell)} = \frac{1}{2} \left[K_{++}^{(\ell)} - K_{--}^{(\ell)} \right] = \frac{1}{2} R^{(\ell)}, \quad (5.18)$$

$$K_{[2]}^{(\ell)} = \frac{1}{4} \left[K_{++}^{(\ell)} + K_{--}^{(\ell)} - 2K_{+-}^{(\ell)} \right] = \frac{1}{4} D^{(\ell)}. \quad (5.19)$$

这个基底经过特意选择, 使 $K_{[1]}^{(\ell)}$ 与 $K_{[2]}^{(\ell)}$ 分别对应两个不同输入的两种自然距离度量——大小之差 $R^{(\ell)}$ 与差的大小 $D^{(\ell)}$ ——并且二者在重合极限下都消失. 剩余分量 $K_{[0]}^{(\ell)}$ 度量总体平均大小, 或者两个第 ℓ 层预激活量的质心大小.

这个基底还有两个稍后会很有用的良好性质: (i) 在交换两个输入的宇称变换 $+\leftrightarrow -$ 下, $K_{[0]}^{(\ell)}$ 与 $K_{[2]}^{(\ell)}$ 都是偶的 (不变的), 而 $K_{[1]}^{(\ell)}$ 是奇的, 其符号随 $+\leftrightarrow -$ 而改变: $K_{[1]}^{(\ell)} \rightarrow -K_{[1]}^{(\ell)}$; (ii) 矩阵 $\gamma^{[a]}$ 彼此正交.⁶⁵

现在用这个新基底讨论重合固定点 (5.12) 附近的扰动. 对于两个无穷接近的输入点 $x_{i,+}$ 与 $x_{i,-}$, 这些扰动有很自然的解释: 它们围绕中点输入 (midpoint input) $x_{i,0} \equiv (x_{i,+} + x_{i,-})/2$ 扰动, 即

$$x_{i,\pm} = x_{i,0} \pm \frac{1}{2}\delta x_i. \quad (5.21)$$

于是, 这些预激活量 $z_{i,\pm}^{(\ell)} \equiv z_i^{(\ell)}(x_{\pm})$ 的动力学, 编码了扰动信号如何随层深 ℓ 在网络中演化. 重合极限对应 $\delta x_i \rightarrow 0$; 退出这一极限时, 应当能够在重合极限值 $K_{[0]}^{(\ell)} = K_{00}^{(\ell)}$ 、 $K_{[1]}^{(\ell)} = K_{[2]}^{(\ell)} = 0$ 附近展开分量 $K_{[a]}^{(\ell)}$. 由此得到展开

$$K_{[0]}^{(\ell)} = K_{00}^{(\ell)} + \delta\delta K_{[0]}^{(\ell)} + O(\delta^4), \quad (5.22)$$

$$K_{[1]}^{(\ell)} = \delta K_{[1]}^{(\ell)} + \delta\delta\delta K_{[1]}^{(\ell)} + O(\delta^5), \quad (5.23)$$

$$K_{[2]}^{(\ell)} = \delta\delta K_{[2]}^{(\ell)} + \delta\delta\delta\delta K_{[2]}^{(\ell)} + O(\delta^6). \quad (5.24)$$

其中, 核扰动关于 δx 的阶数用前置的 δ^p 表示; 我们还利用分量 $K_{[a]}^{(\ell)}$ 在宇称对称性 $+\leftrightarrow -$ 下的奇偶行为, 限制每个展开中可以出现的项.⁶⁶ 接下来将用这些展开判断领先扰动 $\delta K_{[1]}^{(\ell)}$ 与 $\delta\delta K_{[2]}^{(\ell)}$ 在其固定点值附近的行为究竟是指数的、幂律的还是常数的.

为此, 需要把原始核递归 (5.1) 逐阶展开于 δ . 在踏上这段代数旅程之前, 先想想应当预期什么. 在 δ 的零阶, 只会恢复单输入核递归 (5.4):

$$K_{00}^{(\ell+1)} = C_b + C_{wg} \left(K_{00}^{(\ell)} \right). \quad (5.25)$$

这应能消除单输入分析中记号选择的神秘感: 根据 (5.21), $K_{00}^{(\ell)}$ 只是单个输入 x_0 的核, 而 x_0 对应输入对 x_+, x_- 的中点. 此后把 $K_{00}^{(\ell)}$ 称为中点核 (midpoint kernel).⁶⁷

⁶⁵ 这种对称性分解对应物理学家按粒子自旋组织粒子时使用的张量分解. 在操作上, 对任意 2×2 矩阵 $M_{\alpha\beta}$, 可以通过对样本指标取迹并归一化, 把它投影为 $\gamma^{[a]}$ 基底中的分量 $M_{[a]}$:

$$M_{[a]} = \frac{\sum_{\alpha,\beta} M_{\alpha\beta} \gamma_{\beta\alpha}^{[a]}}{\sum_{\alpha,\beta} \gamma_{\alpha\beta}^{[a]} \gamma_{\beta\alpha}^{[a]}}, \quad (5.20)$$

其中 $\alpha, \beta \in \{+, -\}$. 容易验证, 在内积 (5.20) 下, 矩阵 $\gamma_{\alpha\beta}^{[a]}$ 本身彼此正交.

⁶⁶ 当激活函数 $\sigma(z)$ 足够光滑时, 这些展开成立. 对 ReLU 等非光滑激活函数, 展开更为复杂, 但仍可分析. 第 5.5 节将更详细地讨论这些微妙之处.

⁶⁷ 注意, $K_{[0]}^{(\ell)}$ 是第 ℓ 层预激活量之中点 $(z_{i,+}^{(\ell)} + z_{i,-}^{(\ell)})/2$ 的核, 它与传播到第 ℓ 层的中点输入 x_0 之预激活量的中点核 $K_{00}^{(\ell)}$ 并不完全相同. 两者的差异表示在 (5.22) 中, 并且对 δ 展开领先阶的量而言最终可以忽略.

接着, 在 δ 的一阶将得到递归

$$\delta K_{[1]}^{(\ell+1)} = \chi_{\parallel} \left(K_{00}^{(\ell)} \right) \delta K_{[1]}^{(\ell)}. \quad (5.26)$$

这是预料之中的. 由于宇称对称性, 在这一阶 $\delta K_{[1]}^{(\ell+1)}$ 只能正比于 $\delta K_{[1]}^{(\ell)}$; 而比例因子必定就是平行易感率, 因为 $K_{[1]}^{(\ell)} = \frac{1}{2} \left[K_{++}^{(\ell)} - K_{--}^{(\ell)} \right]$ 的行为与单输入核相同: 若单输入核呈指数行为, 这一差值也应如此.

最后, 在 δ 的二阶, 预期递归具有如下形式:

$$\delta \delta K_{[2]}^{(\ell+1)} = [\text{某个量}] \delta \delta K_{[2]}^{(\ell)} + [\text{某个量}'] \left(\delta K_{[1]}^{(\ell)} \right)^2 + [\text{某个量}']' \delta \delta K_{[0]}^{(\ell)}, \quad (5.27)$$

这是由 $\delta \delta K_{[2]}^{(\ell)}$ 的偶宇称对称性所允许的最一般形式, 其中各个“某个量”可以是单输入核 $K_{00}^{(\ell)}$ 的函数. 本小节余下部分将推导 [某个量] 与 [某个量'] 的形式, 同时说明由于矩阵 $\gamma_{\alpha\beta}^{[a]}$ 的正交性, [某个量''] 为零.

在这种启发式分析层面, 方程组的自举性质已经很清楚. 首先求出中点核 $K_{00}^{(\ell)}$ 的解, 它再通过 (5.26) 自举出 $\delta K_{[1]}^{(\ell)}$ 的层依赖性; 后者的解又代入 (5.27), 与 $K_{00}^{(\ell)}$ 一起自举出 $\delta \delta K_{[2]}^{(\ell)}$ 的层依赖性. 换言之, 我们不必直面三个耦合的非线性递归, 而可以逐个求解彼此解耦的递归.

推导自举递归

现在开始这段代数旅程. 目标是把核递归 (5.1) 展开到 δ 的二阶. 这要求计算到该阶的 $\langle \sigma(z_+) \sigma(z_+) \rangle_{K^{(\ell)}}$ 、 $\langle \sigma(z_-) \sigma(z_-) \rangle_{K^{(\ell)}}$ 和 $\langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}}$; 它们都是二维高斯积分. 与其分别处理这些高斯积分, 不如计算任意函数的高斯期望 $\langle F(z_+, z_-) \rangle_{K^{(\ell)}}$, 再分别代入 $F(z_+, z_-) = \sigma(z_+) \sigma(z_+)$ 、 $\sigma(z_-) \sigma(z_-)$ 或 $\sigma(z_+) \sigma(z_-)$. 而且, 后续章节还会用到这个一般表达式 $\langle F(z_+, z_-) \rangle_{K^{(\ell)}}$.

为计算这一高斯期望, 自然应在核的本征基底中, 而不是在坐标 (z_+, z_-) 中写积分. 用 $\{\hat{e}^u, \hat{e}^w\}$ 表示这样的正交归一本征向量, 它们满足本征值方程

$$\sum_{\beta=\pm} K_{\alpha\beta}^{(\ell)} \hat{e}_{\beta}^u = \lambda_u \hat{e}_{\alpha}^u, \quad \sum_{\beta=\pm} K_{\alpha\beta}^{(\ell)} \hat{e}_{\beta}^w = \lambda_w \hat{e}_{\alpha}^w, \quad (5.28)$$

对应本征值分别为 λ_u 与 λ_w . 变换到由

$$z_{\alpha}(u, w) = u \hat{e}_{\alpha}^u + w \hat{e}_{\alpha}^w \quad (5.29)$$

定义的坐标 (u, w) 后, 高斯期望变为

$$\langle F(z_+, z_-) \rangle_{K^{(\ell)}} = \frac{\int du dw \exp\left(-\frac{u^2}{2\lambda_u} - \frac{w^2}{2\lambda_w}\right) F\left(z_+(u, w), z_-(u, w)\right)}{\int du dw \exp\left(-\frac{u^2}{2\lambda_u} - \frac{w^2}{2\lambda_w}\right)}. \quad (5.30)$$

正如第 1.3 节所述, 这个方程表达了如下思想: (u, w) 坐标基底将核对角化, 使分布因子化为 $p(z_+, z_-) = p(u)p(w)$. 分母中的积分表示这一因子化高斯期望的归一化因子.

现在需要实际求出本征值 λ_u, λ_w 与本征向量 $\{\hat{e}^u, \hat{e}^w\}$. 从已经熟悉的重合极限 $\delta \rightarrow 0$ 开始扰动本征分析. 如 (5.22) 附近所述, 在这个极限下核是退化的:

$$K_{\alpha\beta}^{(\ell)} = K_{00}^{(\ell)} \gamma_{\alpha\beta}^{[0]} = K_{00}^{(\ell)} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad (5.31)$$

其中 $\gamma_{\alpha\beta}^{[0]}$ 分量等于中点核 $K_{[0]}^{(\ell)} = K_{00}^{(\ell)}$, 其他分量都消失. 这个矩阵具有归一本征向量

$$\hat{e}_\alpha^u = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \text{以及} \quad \hat{e}_\alpha^w = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad (5.32)$$

对应本征值分别为 $\lambda_u = 2K_{00}^{(\ell)}$ 与 $\lambda_w = 0$.⁶⁸

接下来退出重合极限, 重新考察围绕中点核的 $K_{[0,1,2]}^{(\ell)}$ 的 δ 展开 (5.22)–(5.24). 对本征向量 $\hat{e}_\pm^{u,w}$ 和本征值 $\lambda_{u,w}$ 作类似展开, 即可逐阶求解本征值方程 (5.28).⁶⁹ 完成这些展开 (可以写在页边; 若这不是你的私人藏书, 则写在私人笔记本上), 并把 (5.28) 解到二阶, 得到归一本征向量

$$\begin{aligned} \hat{e}_\alpha^u &= \begin{pmatrix} \hat{e}_+^u \\ \hat{e}_-^u \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 + \frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} - \frac{1}{8} \left(\frac{\delta K_{[1]}^{(\ell)}}{K_{00}^{(\ell)}} \right)^2 \\ 1 - \frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} - \frac{1}{8} \left(\frac{\delta K_{[1]}^{(\ell)}}{K_{00}^{(\ell)}} \right)^2 \end{pmatrix} + O(\delta^3), \\ \hat{e}_\alpha^w &= \begin{pmatrix} \hat{e}_+^w \\ \hat{e}_-^w \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 - \frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} - \frac{1}{8} \left(\frac{\delta K_{[1]}^{(\ell)}}{K_{00}^{(\ell)}} \right)^2 \\ -1 - \frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} + \frac{1}{8} \left(\frac{\delta K_{[1]}^{(\ell)}}{K_{00}^{(\ell)}} \right)^2 \end{pmatrix} + O(\delta^3), \end{aligned} \quad (5.33)$$

以及相应本征值

$$\begin{aligned} \lambda_u &= 2K_{00}^{(\ell)} + 2\delta\delta K_{[0]}^{(\ell)} + \frac{(\delta K_{[1]}^{(\ell)})^2}{2K_{00}^{(\ell)}} + O(\delta^4), \\ \lambda_w &= 2\delta\delta K_{[2]}^{(\ell)} - \frac{(\delta K_{[1]}^{(\ell)})^2}{2K_{00}^{(\ell)}} + O(\delta^4). \end{aligned} \quad (5.34)$$

即使没有私人笔记本, 也很容易在一张草稿纸上验证 (5.33) 与 (5.34) 把 (5.28) 解到了 $O(\delta^2)$.

本征问题解出后, 就可以实施坐标变换. 在此之前, 注意坐标 u 与对应中点输入的预激活量坐标 z_0 密切相关. 因而用 z_0 代替 u 作为坐标十分自然. 可以通过重标度 u

$$\frac{u^2}{2\lambda_u} = \frac{z_0^2}{2K_{00}^{(\ell)}} \quad (5.35)$$

⁶⁸这里, w 的零本征值表示矩阵是退化的. 这意味着 w 坐标的分布由 Dirac delta 函数 $p(w) = \delta(w)$ 给出, 说明在这一极限下实际上只有一个输入.

⁶⁹对物理学家而言, 这就是量子力学中的二阶含时无关微扰理论.

来实现这一点；在积分 (5.30) 中变换变量，使关于 u 的高斯积分成为关于 z_0 的高斯积分，其方差由中点核 $K_{00}^{(\ell)}$ 给出. 经过这一重标度，完整坐标变换成为

$$z_{\pm}(z_0, w) = z_0 \left[1 \pm \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) + \left(\frac{\delta \delta K_{[0]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) + O(\delta^3) \right] + \frac{w}{\sqrt{2}} [\pm 1 + O(\delta)]. \quad (5.36)$$

这里，乘以 w 的方括号内只需保留到 $O(1)$ ，因为 w 坐标均值为零、方差为 $\lambda_w = O(\delta^2)$. 这意味着进行 w 积分时，正比于 w^0 的项为 $O(1)$ ，正比于 w^2 的项为 $O(\delta^2)$ ，更高阶项是次领先的，当然所有奇次项都消失. 相比之下， z_0 坐标均值为零、方差为 $K_{00}^{(\ell)} = O(1)$ ，因此确实需要保留到 $O(\delta^2)$ 的项.

接着，把表达式 (5.36) 代入任意函数

$$F(z_+, z_-) = F(z_+(z_0, w), z_-(z_0, w)), \quad (5.37)$$

现在把它视为两个独立高斯变量 z_0, w 的函数，并对它们积分. 为此，先在 $F(z_0, z_0)$ 附近同时对 δ 与 w 作 Taylor 展开，得到

$$\begin{aligned} & F(z_+, z_-) \\ &= F(z_0, z_0) + z_0 \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) (\partial_+ - \partial_-) F + z_0 \left(\frac{\delta \delta K_{[0]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) (\partial_+ + \partial_-) F, \\ &+ z_0^2 \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right)^2 \frac{(\partial_+ - \partial_-)^2 F}{2} + \frac{w^2 (\partial_+ - \partial_-)^2 F}{2} + \frac{w^2 (\partial_+ + \partial_-)^2 F}{2}, \\ &+ (w \text{ 的奇函数}) + O(\delta^3, w^2 \delta, w^4), \end{aligned} \quad (5.38)$$

其中简记 $\partial_+^p \partial_-^q F \equiv \partial_+^p \partial_-^q F(z_+, z_-)|_{z_+=z_-=z_0}$. 关于 w 的高斯积分很容易完成，只需把 w^2 换成其方差 λ_w ，见 (5.34). 最后，用单变量 z_0 的高斯期望表示答案；回顾一下，其方差由标量中点核 $K_{00}^{(\ell)}$ 给出. 于是

$$\begin{aligned} & \langle F(z_+, z_-) \rangle_{K^{(\ell)}} \\ &= \langle F(z_0, z_0) \rangle_{K_{00}^{(\ell)}} + \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) \langle z_0 (\partial_+ - \partial_-) F \rangle_{K_{00}^{(\ell)}} + \left(\frac{\delta \delta K_{[0]}^{(\ell)}}{2K_{00}^{(\ell)}} \right) \langle z_0 (\partial_+ + \partial_-) F \rangle_{K_{00}^{(\ell)}}, \\ &+ \frac{1}{2} \left\langle \left[\delta \delta K_{[2]}^{(\ell)} + \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right)^2 (z_0^2 - K_{00}^{(\ell)}) \right] (\partial_+ - \partial_-)^2 F \right\rangle_{K_{00}^{(\ell)}} + O(\delta^3). \end{aligned} \quad (5.39)$$

至此，一般期望的计算完成.

为了用这一公式计算核递归 (5.1) 中的期望 $\langle \sigma(z_\alpha) \sigma(z_\beta) \rangle_{K^{(\ell)}}$ ，回顾 (5.16) 中 gamma 矩阵的定义，并注意

$$[\sigma(z_\alpha) \sigma(z_\beta)]|_{z_+=z_-=z_0} = \sigma(z_0) \sigma(z_0) \gamma_{\alpha\beta}^{[0]}, \quad (5.40)$$

$$\{(\partial_+ - \partial_-) [\sigma(z_\alpha) \sigma(z_\beta)]\}|_{z_+=z_-=z_0} = 2\sigma'(z_0) \sigma(z_0) \gamma_{\alpha\beta}^{[1]}, \quad (5.41)$$

$$\{(\partial_+ + \partial_-) [\sigma(z_\alpha) \sigma(z_\beta)]\}|_{z_+=z_-=z_0} = 2\sigma'(z_0) \sigma(z_0) \gamma_{\alpha\beta}^{[0]}, \quad (5.42)$$

$$\{(\partial_+ - \partial_-)^2 [\sigma(z_\alpha) \sigma(z_\beta)]\}|_{z_+=z_-=z_0} = 2\sigma''(z_0) \sigma(z_0) \gamma_{\alpha\beta}^{[0]} + 2\sigma'(z_0) \sigma'(z_0) \gamma_{\alpha\beta}^{[2]}. \quad (5.43)$$

把它们分别代入一般表达式 (5.39), 得到

$$\begin{aligned}
& \langle \sigma(z_\alpha) \sigma(z_\beta) \rangle_{K^{(\ell)}} , \\
&= \left[\langle \sigma(z_0) \sigma(z_0) \rangle_{K_{00}^{(\ell)}} + O(\delta^2) \right] \gamma_{\alpha\beta}^{[0]} , \\
&+ \left[\left(\frac{\delta K_{[1]}^{(\ell)}}{K_{00}^{(\ell)}} \right) \langle z_0 \sigma'(z_0) \sigma(z_0) \rangle_{K_{00}^{(\ell)}} \right] \gamma_{\alpha\beta}^{[1]} , \\
&+ \left[\delta \delta K_{[2]}^{(\ell)} \langle \sigma'(z_0) \sigma'(z_0) \rangle_{K_{00}^{(\ell)}} + \left(\frac{\delta K_{[1]}^{(\ell)}}{2K_{00}^{(\ell)}} \right)^2 \left\langle \left(z_0^2 - K_{00}^{(\ell)} \right) \sigma'(z_0) \sigma'(z_0) \right\rangle_{K_{00}^{(\ell)}} \right] \gamma_{\alpha\beta}^{[2]} .
\end{aligned} \tag{5.44}$$

矩阵 $\langle \sigma(z_\alpha) \sigma(z_\beta) \rangle_{K^{(\ell)}}$ 在 $\gamma_{\alpha\beta}^{[a]}$ 基底中的系数可以直接从上式读出. 因此, 把它代入完整核递归 (5.1) 的右边, 并把左边在这一基底中展开为

$$K_{\alpha\beta}^{(\ell+1)} = K_{[0]}^{(\ell+1)} \gamma_{\alpha\beta}^{[0]} + K_{[1]}^{(\ell+1)} \gamma_{\alpha\beta}^{[1]} + K_{[2]}^{(\ell+1)} \gamma_{\alpha\beta}^{[2]} , \tag{5.45}$$

再令两边对应分量相等, 就得到这一基底中各分量的递归. 它们列在紧接下来的部分.

小结

上面已经说明如何推导如下递归:

$$K_{00}^{(\ell+1)} = C_b + C_W g(K_{00}^{(\ell)}) , \tag{5.46}$$

$$\delta K_{[1]}^{(\ell+1)} = \chi_{\parallel} \left(K_{00}^{(\ell)} \right) \delta K_{[1]}^{(\ell)} , \tag{5.47}$$

$$\delta \delta K_{[2]}^{(\ell+1)} = \chi_{\perp} \left(K_{00}^{(\ell)} \right) \delta \delta K_{[2]}^{(\ell)} + h \left(K_{00}^{(\ell)} \right) \left(\delta K_{[1]}^{(\ell)} \right)^2 . \tag{5.48}$$

这里, 已经熟悉的辅助函数 (5.5) 定义为

$$g(K) = \langle \sigma(z) \sigma(z) \rangle_K ; \tag{5.49}$$

在 (5.10) 中见过的平行易感率为

$$\chi_{\parallel}(K) = C_W g'(K) = \frac{C_W}{2K^2} \langle \sigma(z) \sigma(z) (z^2 - K) \rangle_K = \frac{C_W}{K} \langle z \sigma'(z) \sigma(z) \rangle_K ; \tag{5.50}$$

新引入的垂直易感率 (perpendicular susceptibility) 为

$$\chi_{\perp}(K) \equiv C_W \langle \sigma'(z) \sigma'(z) \rangle_K ; \tag{5.51}$$

而由扰动 $\delta K_{[1]}^{(\ell)}$ 产生扰动 $\delta \delta K_{[2]}^{(\ell+1)}$ 的辅助函数为

$$h(K) \equiv \frac{C_W}{4K^2} \langle \sigma'(z) \sigma'(z) (z^2 - K) \rangle_K = \frac{1}{2} \frac{d}{dK} \chi_{\perp}(K) . \tag{5.52}$$

在 (5.50) 与 (5.52) 的最后一步中, 使用了单变量高斯期望的恒等式

$$\begin{aligned}
\frac{d}{dK} \left[\frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} F(z) \right] &= \frac{1}{2K^2} \left[\frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} F(z) (z^2 - K) \right] \\
&= \frac{1}{2K} \left[\frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} z \frac{d}{dz} F(z) \right] , ,
\end{aligned} \tag{5.53}$$

从第一行到第二行使用了分部积分. 递归 (5.46)–(5.48) 足以完全确定初始化超参数, 并把网络调到临界性.

第一个方程 (5.46) 是中点核 $K_{00}^{(\ell)}$ 的递归. 为分析它, 寻找满足 $K_{00}^* = C_b + C_w g(K_{00}^*)$ 的固定点值 K_{00}^* , 再令 $K_{00}^{(\ell)} = K_{00}^* + \Delta K_{00}^{(\ell)}$, 在该固定点附近线性化. 这样得到 $\Delta K_{00}^{(\ell+1)} = \chi_{\parallel}(K_{00}^*) \Delta K_{00}^{(\ell)} + O(\Delta^2)$, 从而认识到平行易感率 $\chi_{\parallel}(K_{00}^*)$ 支配偏离固定点值 K_{00}^* 的偏差 $\Delta K_{00}^{(\ell)}$ 的增长或衰减.

第二个方程 (5.47) 是伪装后的第一个方程 (5.46), 因为分量 $\delta K_{[1]}^{(\ell)}$ 是两个输入之预激活量大小差 $R^{(\ell)} = (K_{++}^{(\ell)} - K_{--}^{(\ell)})/2$ 的领先项. 因此, 同一个易感率 $\chi_{\parallel}(K_{00}^{(\ell)})$ 支配它的增长或衰减. 另一种看法是, 考虑平行于原输入 $x_{i;0}$ 的扰动 $\delta x_i \propto x_{i;0}$, 会产生两个输入范数之差, 从而生成分量 $\delta K_{[1]}^{(\ell)}$. 这一偏差自然由 $R^{(\ell)}$ 度量; 令 $\chi_{\parallel}(K_{00}^*) = 1$, 便保证这种扰动既不指数爆炸, 也不指数消失. 经过这段漫长旅程, 这终于解释了为何称该易感率为平行易感率.

第三个递归 (5.48) 是新内容, 它控制两个输入之差的大小 $D^{(\ell)} = 4\delta\delta K_{[2]}^{(\ell)} + O(\delta^4)$ 的层依赖性. 如 (5.48) 右边的两项所示, 第 $\ell+1$ 层的这种扰动由第 ℓ 层中的两类扰动驱动. 一项正比于 $(\delta K_{[1]}^{(\ell)})^2$, 由第 ℓ 层中范数不同的预激活量产生. 另一项正比于 $\delta\delta K_{[2]}^{(\ell)}$, 由第 ℓ 层中具有非零差值 $D^{(\ell)}$ 的预激活量产生; 即使预激活量范数相同, 这一项也存在. 在无穷小区间内, 这种等范数扰动对应垂直于中点输入的输入扰动, 即 $\sum_{i=1}^{n_0} x_{i;0} \delta x_i = 0$. 垂直易感率 $\chi_{\perp}(K_{00}^*)$ 决定这种垂直扰动的动力学.⁷⁰ 非零距离 $D^{(\ell)}$ 对于比较经过 ℓ 层传播后的两个输入 $x_{i;\pm}$ 至关重要, 因此必须保证它行为良好. 为避免指数行为, 要求 $\chi_{\perp}(K_{00}^*) = 1$.

综合起来, 一般的临界性概念要求同时满足如下两个条件⁷¹

$$\chi_{\parallel}(K_{00}^*) = 1, \quad \chi_{\perp}(K_{00}^*) = 1, \quad (5.55)$$

其中中点核的固定点值 K_{00}^* 由

$$K_{00}^* = C_b + C_w g(K_{00}^*) \quad (5.56)$$

隐式定义. 这些条件足以保证整个核矩阵在领先阶得到保持, 即

$$\Delta K_{00}^{(\ell+1)} = \Delta K_{00}^{(\ell)} + O(\Delta^2), \quad K_{[1]}^{(\ell+1)} = K_{[1]}^{(\ell)} + O(\delta^3), \quad K_{[2]}^{(\ell+1)} = K_{[2]}^{(\ell)} + O(\delta^4). \quad (5.57)$$

⁷⁰另一种看法是, 对网络的给定实例, 垂直易感率 $\chi_{\perp}(K_{00}^{(\ell)})$ 控制预激活量随输入改变而发生的变化. 为看清这一点, 注意距离 $D^{(\ell)}$ 在扰动领先阶可改写为

$$D^{(\ell)} = \frac{1}{n_{\ell}} \sum_{i=1}^{n_{\ell}} \mathbb{E} \left[\left(z_{i;+}^{(\ell)} - z_{i;-}^{(\ell)} \right)^2 \right] = \frac{1}{n_{\ell}} \sum_{i=1}^{n_{\ell}} \mathbb{E} \left[\left(\sum_{j=1}^{n_0} \frac{dz_{i;0}^{(\ell)}}{dx_{j;0}} \delta x_j \right)^2 \right] + O(\delta^4). \quad (5.54)$$

这使量 $\chi_{\perp}(K_{00}^*)$ 与控制著名的梯度爆炸与消失问题有关; 第 9 章会使这一视角更具体.

⁷¹这进一步凸显了系综的必要性. 在第 2.3 节中, 我们指出零初始化 $b_i^{(\ell)} = W_{ij}^{(\ell)} = 0$ 不会打破一层的 n_{ℓ} 个神经元之间的置换对称性, 以此论证初始化分布的必要性. 这里更一般地看到, 任何零均值确定性权重分布 (即 $C_w = 0$) ——包括零初始化——都无法满足临界性条件 $\chi_{\parallel} = \chi_{\perp} = 1$, 因为易感率 (5.50) 与 (5.51) 都正比于 C_w . 这种零权重初始化总会指数衰减到 $K_{00}^* = C_b$ 处的平凡固定点.

这推广了第 3 章为深度线性网络讨论的临界性概念. 接下来的两节将给出一套方案, 为任意非线性激活函数寻找临界初始化超参数 $(C_b, C_W)^{\text{critical}}$.

5.2 尺度不变激活函数的临界性

现在, 将刚刚建立的形式体系用于尺度不变性激活函数, 把我们的临界性分析推广到这类函数. 回顾第 2.2 节, 尺度不变激活函数满足

$$\sigma(\lambda z) = \lambda \sigma(z), \quad (5.58)$$

其中正重标度因子可取任意值 $\lambda > 0$; 而且这种函数总具有如下形式:

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0. \end{cases} \quad (5.59)$$

作为提醒, 这类激活函数包括 linear 激活函数——令 $a_+ = a_- = 1$ ——以及 ReLU——令 $a_+ = 1$ 且 $a_- = 0$.

这些激活函数格外简单, 因为临界性条件 (5.55), 即 $\chi_{\parallel}(K_{00}^{(\ell)}) = \chi_{\perp}(K_{00}^{(\ell)}) = 1$, 可以精确求解. 首先很容易计算式 (5.49) 中的 $g(K)$: 它化为实轴两个半轴上的高斯积分乘以偶多项式, 结果为

$$g(K) = A_2 K, \quad (5.60)$$

其中引入了依赖于激活函数的常数

$$A_2 \equiv \frac{a_+^2 + a_-^2}{2}. \quad (5.61)$$

由式 (5.50) 可见, 对上式关于 K 求导再乘以 C_W , 即可得到 $\chi_{\parallel}(K)$. 考察式 (5.51) 可知, 为得到 $\chi_{\perp}(K)$, 只需在实轴两个半轴上再做两个简单的高斯积分. 于是两个易感率相等, 而且均与 $K_{00}^{(\ell)}$ 无关:

$$\chi_{\parallel}(K_{00}^{(\ell)}) = \chi_{\perp}(K_{00}^{(\ell)}) = A_2 C_W \equiv \chi. \quad (5.62)$$

最后, 式 (5.52) 中的 $h(K)$ 恒为零, 因为它是 $\chi_{\perp}(K)$ 的导数.

利用这些结果, 尺度不变激活函数的一般核递归 (5.46)、(5.47) 和 (5.48) 可写为

$$K_{00}^{(\ell+1)} = C_b + \chi K_{00}^{(\ell)}, \quad (5.63)$$

$$\delta K_{[1]}^{(\ell+1)} = \chi \delta K_{[1]}^{(\ell)}, \quad (5.64)$$

$$\delta \delta K_{[2]}^{(\ell+1)} = \chi \delta \delta K_{[2]}^{(\ell)}. \quad (5.65)$$

这些递归很容易求解. 正如初始化超参数 C_W 控制第 3.2 节中的核爆炸与消失问题一样, 这里的常数易感率 $\chi = A_2 C_W$ 控制同一个问题:

- 若 $\chi > 1$, 所有量都随 ℓ 指数爆炸, 趋向无穷远处的一个平凡固定点.

- 若 $\chi < 1$, 核的固定点值为 $K_{00}^* = \frac{C_b}{1-\chi}$, 固定点附近的所有扰动都随 ℓ 指数消失.
- 若 $C_W = 1/A_2$ 且 $C_b = 0$, 网络便处于临界性. 不仅每种扰动都保持不变,⁷² 而且 K_{00}^* 的任意取值都是非平凡固定点, 即存在一条非平凡固定点线.⁷³ 特别地, 固定点的值为

$$K_{00}^* = \frac{1}{A_2} \left(\frac{1}{n_0} \sum_{i=1}^{n_0} x_{i;0}^2 \right). \quad (5.66)$$

- 若 $C_W = 1/A_2$ 且 $C_b > 0$, 则在这一无穷小分析层次上, $\delta K_{[1]}^{(\ell)}$ 与 $\delta \delta K_{[2]}^{(\ell)}$ 保持不变. 然而, $K_{00}^{(\ell)}$ 会以 C_b 设定的速率线性增长, 趋向无穷远处的一个非平凡固定点. 由于核不呈现任何指数行为, 这样的网络在广义上处于临界性. 这种半临界性在由 (C_b, C_W) 张成的超参数平面上给出一条由 C_b 参数化的半临界初始化超参数线.

总之, 这项研究推广了第 3.2 节对深度线性网络所作的分析, 并确定尺度不变激活函数的临界初始化超参数为

$$(C_b, C_W)^{\text{critical}} = \left(0, \frac{1}{A_2} \right), \quad (5.67)$$

其中 $A_2 = (a_+^2 + a_-^2)/2$.⁷⁴ 对 ReLU 激活函数, 这重现了 *Kaiming* 初始化 $(C_b, C_W)^{\text{critical}} = (0, 2)$ [48].

5.3 超越尺度不变激活函数的普适性

上一节处理的所有激活函数都有一个相当特殊的性质: 式 (5.58) 所定义的尺度不变性. 这一性质使平行易感率与垂直易感率相等且与核无关, 即 $\chi_{\parallel}(K) = \chi$, $\chi_{\perp}(K) = \chi$; 这些性质共同使我们能够大幅简化对这类激活函数的临界性分析.⁷⁵ 该分析表明, 在临界性处, 采用尺度不变激活函数的网络在表征群流下彼此具有相似行为.

在理论物理学中, 临界点处在重整化群流下表现相似的系统被称为属于同一个普适类. 描述这些系统的有效作用量在迭代粗粒化过程中收敛, 使这些系统在长程尺度上共享同一个底层数学模型或有效理论, 而与具体系统的微观细节无关. 这一现象称为普适性 [49].

这启发我们使用同一个术语“普适类”来刻画在表征群流下具有相同极限行为的激活函数, 从而进一步发展第 4.6 节开始建立的 RG 流与 RG 流之间的联系. 构成一个普适类的激活函数在流过许多层后具有相同的有效描述; 换言之, 描述预激活量分布的有

⁷² 这里需要说明一点. 预激活范数 $K_{[0]}^{(\ell)}$ 和平行扰动 $K_{[1]}^{(\ell)}$ 的恒定性是精确的, 但 $K_{[2]}^{(\ell)}$ 的恒定性只是无穷小扰动分析的产物. 事实上, 第 5.5 节对非线性尺度不变激活函数所作的有限角分析表明: $K_{[2]}^{(\ell)}$ 会从小 ℓ 时近乎恒定, 过渡到大 ℓ 时按幂律 $\sim 1/\ell^2$ 衰减. 简言之, 第 3.2 节中整个核矩阵的保持是 **linear** 激活函数的一项特殊性质; 对于非线性尺度不变激活函数, 某些可观测量会缓慢地按幂律衰减. 与指数行为相比, 这种幂律行为相当温和, 也是临界性的典型特征.

⁷³ 对物理学家而言, 可以注意到: 在具有严格边缘形变的尺度不变场论中, 也常常出现类似的固定点线.

⁷⁴ 由此可见, 第 3 章对深度线性网络取 $C_b = 0$ 的简化, 事后看来完全合理.

⁷⁵ 与核无关这一性质直接源于尺度不变性, 因为任何依赖关系都会把一个尺度引入问题.

效理论将不再依赖具体激活函数的细节. 普适性的威力在于, 一个有效理论就能帮助我们理解同一普适类中许多不同激活函数的临界性.

显然, 所有尺度不变激活函数构成一个普适类. 然而, 使我们能轻松分析这一**尺度不变普适类**的简化性质——例如易感率与核无关——对其他激活函数并不成立. 对于 sigmoid、tanh 或 SWISH 等激活函数, 需要建立一种更一般的算法来寻找临界初始化超参数. 第 5.3.1 节将说明该算法如何工作, 随后在第 5.3.2、5.3.3 和 5.3.4 节分析具体的激活函数.

5.3.1 一般策略

先回顾一些结果. 正如最近在第 5.1 节讨论的那样, 对初始化超参数 C_b 和 C_W 的一般选择, 单输入 x_0 的核递归

$$K_{00}^{(\ell+1)} = C_b + C_W g(K_{00}^{(\ell)}), \quad (5.68)$$

允许一个满足

$$K_{00}^* = C_b + C_W g(K_{00}^*), \quad (5.69)$$

的固定点解, 其中辅助函数

$$g(K) \equiv \langle \sigma(z) \sigma(z) \rangle_K, \quad (5.70)$$

被理解为核值 K 的函数. 我们的目标是找到临界初始化超参数, 使其对应的固定点值 $K_{00}^* = K_{00}^*(C_b, C_W)$ 满足 $\chi_{\parallel}(K_{00}^*) = \chi_{\perp}(K_{00}^*) = 1$.

究竟如何找到这些临界值? 从概念上说, 最显然的途径如下; 图 5.1 用 tanh 激活函数说明了这一过程:

1. 对 $C_b \geq 0$ 、 $C_W \geq 0$ 的每一组 C_b 与 C_W , 寻找核的一个固定点值 $K_{00}^* = K_{00}^*(C_b, C_W)$; 它由 $K_{00}^* = C_b + C_W g_0(K_{00}^*)$ 隐式定义, 并受约束 $K_{00}^* \geq 0$.
2. 给定 $K_{00}^*(C_b, C_W)$, 计算 $\chi_{\parallel}(K_{00}^*)$ 与 $\chi_{\perp}(K_{00}^*)$, 并扫描 (C_b, C_W) 平面中的取值, 直到临界性条件 $\chi_{\parallel} = 1$ 与 $\chi_{\perp} = 1$ 同时满足.

然而, 对一般激活函数, 无论从数值上还是解析上, 这种算法在实践中都很繁琐. 为得到更便于实现的算法, 稍微重排一下逻辑. 首先注意, 对候选固定点值 K_{00}^* , 取

$$C_W = \left[\langle \sigma'(z) \sigma'(z) \rangle_{K_{00}^*} \right]^{-1}, \quad (5.71)$$

$$C_b = K_{00}^* - \frac{\langle \sigma(z) \sigma(z) \rangle_{K_{00}^*}}{\langle \sigma'(z) \sigma'(z) \rangle_{K_{00}^*}}, \quad (5.72)$$

便会同时满足固定点方程 $K_{00}^* = C_b + C_W g_0(K_{00}^*)$ 与第一个临界性条件 $\chi_{\perp}(K_{00}^*) = 1$. 第二个临界性条件 $\chi_{\parallel}(K_{00}^*) = 1$ 此时等价于 $\chi_{\perp}(K_{00}^*) / \chi_{\parallel}(K_{00}^*) = 1$, 即如下期望之比:

$$\left[\frac{2K^2 \langle \sigma'(z) \sigma'(z) \rangle_K}{\langle \sigma(z) \sigma(z) (z^2 - K) \rangle_K} \right] \bigg|_{K=K_{00}^*} = 1, \quad (5.73)$$

它与初始化超参数 C_W 和 C_b 无关. 因此, 可以使用下面这个更简单的算法:




图 5.1: 确定非平凡固定点的两种算法, 这里以 $\tanh$ 激活函数为例. 左: 在 $\tanh$ 激活函数的超参数平面 (C_W, C_b) 中, 画出条件 $\chi_{\perp}^* = 1$ (实线) 与 $\chi_{\parallel}^* = 1$ (虚线) 所定义的曲线. 两条曲线的交点给出临界初始化超参数 $(C_W, C_b) = (1, 0)$. 右: 条件 (5.73) 的左侧被画成 K_{00}^* 的函数; 当 $K_{00}^* \rightarrow 0$ 时, 曲线达到 1.

1. 扫描 $K_{00}^* \geq 0$ 的取值, 直到满足式 (5.73).
2. 把所得 K_{00}^* 代入式 (5.71) 和 (5.72), 计算临界初始化超参数, 并同时确认 $C_b \geq 0$.

图 5.1 把式 (5.73) 的左侧画成 $\tanh$ 激活函数下 K_{00}^* 的函数, 可以看到它在 $K_{00}^* = 0$ 时达到 1. 随后, 在 $K_{00}^* \rightarrow 0$ 极限下计算式 (5.71) 与 (5.72), 即可高效得到 $\tanh$ 的临界初始化超参数 $(C_W, C_b) = (1, 0)$.⁷⁶

顺便指出, 尺度不变激活函数对任意固定点值 K_{00}^* 都平凡地满足条件 (5.73), 因为两个易感率都等于同一个与核无关的常数: $\chi_{\parallel}(K) = \chi_{\perp}(K) = \chi$. 很容易验证, 对这一普适类, 上述算法会恢复第 5.2 节给出的临界初始化超参数 (5.67).

5.3.2 不存在临界性: sigmoid、softplus、非线性单项式等

对于某些激活函数, 核不存在非平凡固定点. 例如, 考虑 sigmoid 激活函数

$$\sigma(z) = \frac{1}{1 + e^{-z}}. \quad (5.74)$$

图 5.2 针对这一激活函数画出了条件 (5.73). 尽管该条件在 $K_{00}^* = 0$ 处成立, 但在这一极限下计算式 (5.72) 得到 $C_b = -\left(\frac{\sigma(0)}{\sigma'(0)}\right)^2 < 0$. 偏置的方差不可能为负, 因此这并不符合物理要求.⁷⁷ 所以, sigmoid 无法调谐到临界性, 不应使用.⁷⁸

⁷⁶ 尽管中点核的固定点值为零, 但这是一个非平凡固定点. 特别地, 第 5.3.3 节将看到, 在 $K_{00}^* = 0$ 处具有非平凡固定点的核构成一个普适类, 其特征是随 ℓ 呈温和的幂律衰减. 在实践中, 这种幂律行为意味着: 对任意有限深度, 核都保持有限.

⁷⁷ 极限值 $C_b = -\left(\frac{\sigma(0)}{\sigma'(0)}\right)^2$ 暗示: 要使激活函数具有非平凡固定点, 条件 $\sigma(0) = 0$ 与 $\sigma'(0) \neq 0$ 可能是必要约束.

⁷⁸ 类似地, 作为 logistic 函数的非光滑极限, perceptron 激活函数甚至更糟, 不值得讨论.




图 5.2: 把条件 (5.73) 的左侧画成 K_{00}^* 的函数: 左图对应 `sigmoid` 激活函数, 右图对应 `softplus` 激活函数. 对 `sigmoid`, 当 $K_{00}^* \rightarrow 0$ 时曲线达到 1, 但相应的临界初始化超参数 (C_b, C_W) 因 $C_b < 0$ 而不符合物理要求. 对 `softplus`, 曲线没有达到 1. 这些激活函数都无法调谐到临界性.

接着考虑 `softplus` 激活函数

$$\sigma(z) = \log(1 + e^z), \quad (5.75)$$

回顾一下, 它是 `ReLU` 的光滑近似. 在图 5.2 中画出条件 (5.73) 后可以看到, 对任意 $K_{00}^* \geq 0$, 该条件都无法满足. 因此, 与 `ReLU` 不同, `softplus` 无法调谐到临界性. 尽管两者相似而且 `softplus` 光滑, 这一结果支持了领域内关于 `ReLU` 优于 `softplus` 的普遍看法.

下一小节将看到, 这些激活函数的真正问题在于它们在 $z = 0$ 处不穿过零点. 有一个简单修复方法: 通过对每个激活函数作适当的常数平移, 令

$$\sigma(0) = 0. \quad (5.76)$$

作此平移后, `sigmoid` 会变成 `tanh`, 不过预激活量与激活量都各自缩放为一半. 这种缩放后的 `tanh` 确实允许临界初始化; 读完下一小节的讨论后, 很容易验证这一点.

据此, 再看在零点处以非线性方式穿过零点的激活函数会怎样. 为简单起见, 取任意非线性 `monomial` (单项式) 激活函数

$$\sigma(z) = z^p, \quad p = 2, 3, 4, \dots \quad (5.77)$$

在这种情形下, 直接进行高斯积分会把条件 (5.73) 化为约束

$$\frac{p}{2p-1} = 1, \quad (5.78)$$

由于 $p \neq 1$, 非线性单项式无法满足这一约束. 因而, 这类非线性单项式同样不应在深层网络中使用. 更重要的是, 除了 $\sigma(0) = 0$ 外, 临界性似乎还要求条件

$$\sigma'(0) \neq 0, \quad (5.79)$$

下一小节将更一般地研究这一条件.

本小节讨论的所有激活函数都不可能具有临界性, 这意味着不应鼓励使用它们. 对浅层网络而言, 这个问题有所缓解——因为层数较少, 指数行为损害信号的机会也较少——但随着网络越来越深, 临界性会变得越来越不可或缺.

5.3.3 $K^* = 0$ 普适类: $\tanh$ 、 $\sin$ 等

在第 5.3.1 节中, 我们通过数值研究得知, $\tanh$ 在 $K_{00}^* = 0$ 处有一个非平凡固定点. 此外, 上一小节 5.3.2 的分析表明, 对任意光滑激活函数, 条件 $\sigma(0) = 0$ 与 $\sigma'(0) \neq 0$ 对存在非平凡固定点很重要.

本小节将联系这两项观察. 具体而言, 在 $K_{00}^* = 0$ 附近, 可以围绕 $K_{00}^* = 0$ 作 Taylor 展开并直接计算高斯期望, 从而解析分析核递归 (5.46)–(5.48). 该分析将表明: 光滑激活函数在 $K_{00}^* = 0$ 处具有非平凡固定点, 当且仅当 $\sigma(0) = 0$ 且 $\sigma'(0) \neq 0$; 由此定义我们的第二个普适类.

对任意解析激活函数, 采用如下 Taylor 系数记号:

$$\sigma(z) = \sum_{p=0}^{\infty} \frac{\sigma_p}{p!} z^p. \quad (5.80)$$

把这一展开代入辅助函数 (5.70) 的定义并进行高斯积分, 得到

$$g(K) = \langle \sigma(z)\sigma(z) \rangle_K = \sigma_0^2 + (\sigma_1^2 + 2\sigma_0\sigma_2) K + O(K^2). \quad (5.81)$$

由此可见, 中点核递归的固定点

$$K_{00}^* = C_b + C_W g(K_{00}^*), \quad (5.82)$$

在 $K_{00}^* = 0$ 处有解, 当且仅当 $C_b = C_W \sigma_0^2 = 0$. 回顾 $C_W = 0$ 违反临界性条件, 所以必须选择 $\sigma_0 = 0$. 下文将假定已经作出这一选择.

继续取 $\sigma_0 = 0$ 与 $C_b = 0$, 把展开式 (5.80) 代入易感率表达式 (5.50) 和 (5.51) 并进行高斯积分, 得到

$$C_W g(K) = (C_W \sigma_1^2) [K + a_1 K^2 + a_2 K^3 + O(K^4)], \quad (5.83)$$

$$\chi_{\parallel}(K) = (C_W \sigma_1^2) [1 + 2a_1 K + 3a_2 K^2 + O(K^3)], \quad (5.84)$$

$$\chi_{\perp}(K) = (C_W \sigma_1^2) [1 + b_1 K + O(K^2)], \quad (5.85)$$

这里还把 $g(K)$ 展开到核的更高阶; 系数 a_1 、 a_2 和 b_1 由激活函数 Taylor 系数的如下组合给出:

$$a_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \frac{3}{4} \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (5.86)$$

$$a_2 \equiv \frac{1}{4} \left(\frac{\sigma_5}{\sigma_1} \right) + \frac{5}{8} \left(\frac{\sigma_4}{\sigma_1} \right) \left(\frac{\sigma_2}{\sigma_1} \right) + \frac{5}{12} \left(\frac{\sigma_3}{\sigma_1} \right)^2, \quad (5.87)$$

$$b_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (5.88)$$

很容易验证, 例如对 $\tanh$, 这些系数取值为 $a_1 = -2$ 、 $a_2 = 17/3$ 、 $b_1 = -2$. 现在考察展开式 (5.84) 与 (5.85): 为了满足临界性条件 $\chi_{\parallel}(K_{00}^* = 0) = 1$ 与 $\chi_{\perp}(K_{00}^* = 0) = 1$, 必须令 $C_W = 1/\sigma_1^2$. 为保证方差有限, 还必须有 $\sigma_1 \neq 0$.

因此, 任意光滑激活函数要在 $K_{00}^* = 0$ 处具有非平凡固定点, 必要且充分的是 $\sigma(z)$ 满足

$$\sigma_0 = 0, \quad \sigma_1 \neq 0. \quad (5.89)$$

对这样的激活函数, 临界初始化超参数为

$$(C_b, C_W)^{\text{critical}} = \left(0, \frac{1}{\sigma_1^2}\right). \quad (5.90)$$

再次强调, 任意满足条件 (5.89) 并按式 (5.90) 初始化的激活函数, 都会在 $K_{00}^* = 0$ 处有一个非平凡固定点. 在原点取零且一阶导数非零的激活函数集合构成 $K^* = 0$ 普适类. 这一类的典型成员是 $\tanh$ 激活函数; 当然, 该类还有非常多的其他成员, 例如 $\sin$ 激活函数也属于这一类.

确定临界初始化超参数后, 现在来理解 $K^* = 0$ 普适类中核的行为. 我们将看到, 满足式 (5.89) 的激活函数在调谐到临界性后, 在 RG 流下全都表现相似; 核的大深度行为只依赖于 $\sigma(z)$ 的前几个 Taylor 系数.

中点核的深度渐近分析

回忆固定点附近的展开 $K_{00}^{(\ell)} = K_{00}^* + \Delta K_{00}^{(\ell)}$, 并考虑 $g(K)$ 的展开式 (5.83). 在 $K_{00}^* = 0$ 的临界性下, 中点核递推变为

$$\Delta K_{00}^{(\ell+1)} = \Delta K_{00}^{(\ell)} + a_1 \left(\Delta K_{00}^{(\ell)}\right)^2 + a_2 \left(\Delta K_{00}^{(\ell)}\right)^3 + O\left(\left(\Delta K_{00}^{(\ell)}\right)^4\right). \quad (5.91)$$

临界性的要义正在于缓解指数行为, 因此我们预期核会以更温和的方式衰减回到 $K_{00}^{(\ell)} = 0$ 固定点. 据此, 将幂律拟设 $\Delta K_{00}^{(\ell)} \sim (1/\ell)^{p_0}$ 代入式 (5.91). 注意到 $(1/(\ell+1))^{p_0} = \ell^{-p_0} [1 - p_0/\ell + O(1/\ell^2)]$, 匹配两边的领头项便得到解

$$\Delta K_{00}^{(\ell)} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \dots \quad (5.92)$$

因此, 临界性处的行为是温和的幂律衰减, 其临界指数 (critical exponent) 为 $p_0 = 1$. 这个指数对 $K^* = 0$ 普适类而言是普适的, 因为它完全不依赖于具体激活函数的细节.

重要的是, 要使这个渐近解自洽, 必须有 $(-a_1) > 0$, 以确保核为正. 如果反而有 $(-a_1) < 0$, 渐近解 (5.92) 就会为负, 因而无效. 此时固定点不稳定, 会以指数方式把核从 $K_{00}^* = 0$ 排斥开来.⁷⁹ 下一小节将看到, SWISH 和 GELU 激活函数在 $K_{00}^* = 0$ 附近确实表现出这种不稳定性.

此外, 上一小节曾提出, 不满足 $\sigma(0) = 0$ 的激活函数或许可通过常数平移挽救. 特别地, 能否从 `softplus` 中减去常数 $\log(2)$, 使其满足 $\sigma(0) = 0$? 然而, 此时会有

⁷⁹一般而言, $(-a_1) < 0$ 意味着在 $K_{00}^* = 0$ 之外 $\chi_{\parallel} > 1$, 这会先以幂律、继而以指数方式排斥中点核. 不过, 我们在第 5.2 节讨论的尺度不变激活函数的半临界性是例外. 对该普适类, $a_1 = 0$, 因此朝无穷远固定点的增长由幂律支配.

$(-a_1) < 0$, 核将被唯一候选的非平凡固定点 $K_{00}^* = 0$ 排斥. 又因为在 $K = 0$ 之外 $\chi_{||}(K) > 1$, 中点核将以指数方式发散. 因而尽管做了这种尝试, `softplus` 仍无法挽救.

回到解 (5.92), 对次领头渐近分析而言, 我们其实可以比 “...” 做得好得多. 改进拟设的第一种猜想, 是在 $\Delta K_{00}^{(\ell)}$ 中加入次领头的 $1/\ell^2$ 项. 但若尝试匹配式 (5.91) 两边的各项, 就会发现无法消去 $1/\ell^3$ 项. 可行的办法是再向拟设中加入系数独立的 $\log(\ell)/\ell^2$ 项. 它会生成额外的 $1/\ell^3$ 项, 从而允许自洽解. 一般地, 对下文考察的任一可观测量 $\mathcal{O}^{(\ell)}$, 其大 ℓ 渐近展开的正确标度拟设 (scaling ansatz) 具有形式

$$\begin{aligned}\mathcal{O}^{(\ell)} &= \left(\frac{1}{\ell}\right)^{p_{\mathcal{O}}} \left[c_{0,0} + c_{1,1} \left(\frac{\log \ell}{\ell}\right) + c_{1,0} \left(\frac{1}{\ell}\right) + c_{2,2} \left(\frac{\log^2 \ell}{\ell^2}\right) + \dots \right] \\ &= \left(\frac{1}{\ell}\right)^{p_{\mathcal{O}}} \left[\sum_{s=0}^{\infty} \sum_{q=0}^s c_{s,q} \left(\frac{\log^q \ell}{\ell^s}\right) \right],\end{aligned}\quad (5.93)$$

其中临界指数 $p_{\mathcal{O}}$ 对给定普适类应当是普适的, 而常数 $c_{s,q}$ 则依赖于具体激活函数的细节. 对 $\mathcal{O}^{(\ell)} = \Delta K_{00}^{(\ell)}$ 继续这一过程, 可系统确定核扰动的次领头行为:

$$\begin{aligned}\Delta K_{00}^{(\ell)} &= \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \left[\frac{-(a_2 - a_1^2)}{a_1^3} \right] \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell^2} \\ &\quad + \left[\frac{-(a_2 - a_1^2)^2}{a_1^5} \right] \frac{\left[\log\left(\frac{\ell}{\ell_0}\right)\right]^2}{\ell^3} + \left[\frac{(a_2 - a_1^2)^2}{a_1^5} \right] \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell^3} + O\left(\frac{1}{\ell^3}\right).\end{aligned}\quad (5.94)$$

只要投入足够精力, 按照标度拟设 (5.93) 纳入更高阶修正, 就能把这一渐近展开细化到任意阶.

这里的常数 ℓ_0 无法由大 ℓ 渐近分析确定, 并通过

$$K_{00}^{(1)} = \frac{1}{\sigma_1^2} \frac{1}{n_0} \sum_{i=1}^{n_0} x_{i,0}^2, \quad (5.95)$$

非平凡地依赖于输入范数. 当重标度权重方差取临界值 $C_W = 1/\sigma_1^2$ 时, 这个等式为核递推 (5.1) 设定初始条件 (5.2). 为理解其含义, 假设 $\chi_{||}(K)$ 在 $K \geq 0$ 上单调递减且 $\chi_{||}(0) = 1$ ——`tanh` 的确如此——再考察输入 $x_{i,0}$ 幅值很大的情形. 这种大范数输入会使第一层中点核很大, 即 $K_{00}^{(1)} \gg 1$. 对某个常数 $k_{\#}$, 在 $0 < k_{\#} < K_{00}^{(\ell)}$ 的范围内, 核 $K_{00}^{(\ell)}$ 的衰减会快于 $\chi_{||}(k_{\#})^{\ell}$, 其中 $\chi_{||}(k_{\#}) < 1$; 这一过程持续到它进入 $K_{00}^* = 0$ 附近的幂律区间. 未定常数 ℓ_0 正是这种复杂交叉行为的遗迹, 它承载着中点核领头的数据依赖性.

此外, 中点核的渐近展开 (5.94) 在 RG 流下还有一种很好的解释. 衰减的临界指数 $p_0 = 1$ 对该普适类是一般性的; 但各项系数的确依赖于激活函数的细节, 尽管只依赖前几个 Taylor 系数. 事实上, 随着 ℓ 越来越大, 这种依赖涉及的系数越来越少, 而领头项仅依赖式 (5.86) 中的 a_1 . 在这一渐近极限下, $K^* = 0$ 普适类中任何在零点附近具有相同前三个 Taylor 系数的激活函数都完全无法区分. 因此, 从表征群流的视角看, 网络变深的一个结果, 就是使激活函数的具体细节变得越来越无关紧要.

最后, 对所有有志于 “设计激活函数” 的读者指出: 通过微调激活函数的 Taylor 系数, 可以构造不同于 $p_0 = 1$ 的临界指数. 例如, 若通过平衡 σ_3 与 σ_2 令 $a_1 = 0$, 那么

只要 $(-a_2) > 0$, 核就会以 $1/\sqrt{\ell}$ 幂律衰减趋近 $K_{00}^* = 0$ 的非平凡固定点. 这种调谐的必要性表明, 对 $K^* = 0$ 普适类中的激活函数而言, $\sim 1/\ell$ 行为是一般性的.⁸⁰

平行扰动的深度渐近分析

接下来求解平行扰动的 $\delta K_{[1]}^{(\ell)}$ 递推. 将 $\chi_{\parallel}(K)$ 的展开式 (5.84) 代入递推式 (5.47), 得到代数方程

$$\delta K_{[1]}^{(\ell+1)} = \left[1 + 2a_1 \Delta K_{00}^{(\ell)} + 3a_2 \left(\Delta K_{00}^{(\ell)} \right)^2 + O\left(\left(\Delta K_{00}^{(\ell)} \right)^3 \right) \right] \delta K_{[1]}^{(\ell)}. \quad (5.96)$$

然后代入 $\Delta K_{00}^{(\ell)}$ 的大 ℓ 解 (5.94), 并依据标度拟设 (5.93) 对 $\delta K_{[1]}^{(\ell)}$ 作大 ℓ 渐近展开. 匹配所得方程两边的各项, 便可解得

$$\delta K_{[1]}^{(\ell)} = \frac{\delta_{\parallel}}{\ell^2} \left[1 + \frac{2a_1 (a_2 - a_1^2)}{a_1^3} \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell} + O\left(\frac{1}{\ell}\right) \right], \quad (5.97)$$

考察这个解, 可以辨认出 $K^* = 0$ 普适类的第二个临界指数: $p_{\parallel} = 2$, 对应于 $\delta K_{[1]}^{(\ell)}$ 的 $1/\ell^2$ 衰减. 这个指数的具体取值符合预期. 如前所述, 对范数不同的两个输入, 平行扰动恰是它们单输入核之差, 即 $K_{[1]}^{(\ell)} = (K_{++}^{(\ell)} - K_{--}^{(\ell)})/2$. 之所以出现领头的 $1/\ell^2$ 标度, 是因为对角分量 $K_{++}^{(\ell)}$ 与 $K_{--}^{(\ell)}$ 直到 $\log(\ell)/\ell^2$ 阶都由相同的渐近行为支配, 包括相同的系数. 因而领头差异出现在 $1/\ell^2$ 阶, 来源是 $K_{++}^{(\ell)}$ 与 $K_{--}^{(\ell)}$ 各自类似于式 (5.94) 的展开中, 输入依赖常数 ℓ_+ 与 ℓ_- 不同; 未定常数满足 $\delta_{\parallel} \propto \log(\ell_+/\ell_-)$. 这样一来, 该常数就明确承载了平行扰动的数据依赖性.

垂直扰动的深度渐近分析

最后, 通过求解垂直扰动的 $\delta\delta K_{[2]}^{(\ell)}$ 递推来结束本节分析. 首先把 $\chi_{\perp}(K)$ 的展开式 (5.85) 代入递推式 (5.48). 由于我们要关注满足 $\sum_{i=1}^{n_0} x_{i;0} \delta x_i = 0$ 的垂直扰动, 还令 $\delta K_{[1]}^{(\ell)} = 0$ 以关闭平行扰动. 合并这些条件得到代数方程

$$\delta\delta K_{[2]}^{(\ell+1)} = \left[1 + b_1 \Delta K_{00}^{(\ell)} + O\left(\left(\Delta K_{00}^{(\ell)} \right)^2 \right) \right] \delta\delta K_{[2]}^{(\ell)}. \quad (5.98)$$

代入 $\Delta K_{00}^{(\ell)}$ 的大 ℓ 渐近解, 再依据标度拟设 (5.93) 对 $\delta\delta K_{[2]}^{(\ell)}$ 作另一个大 ℓ 渐近展开并求解所得方程, 得到

$$\delta\delta K_{[2]}^{(\ell)} = \frac{\delta^2}{\ell^{\frac{b_1}{a_1}}} \left[1 + \frac{b_1 (a_2 - a_1^2)}{a_1^3} \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell} + O\left(\frac{1}{\ell}\right) \right], \quad (5.99)$$

其中 δ^2 是另一个无法由大 ℓ 解确定的未定常数; 在这里, 它以非平凡方式关联于输入之差的大小 $\sum_{i=1}^{n_0} (x_{i;+} - x_{i;-})^2$. 由此可见, 暂定的临界指数 $p_{\perp} \equiv b_1/a_1$ 略微依赖于激活函数的细节.

⁸⁰更准确地说, 我们本应在定义 $K^* = 0$ 普适类时要求 $a_1 \neq 0$. 这又会引导我们定义一整族普适类: 它们可由 a_1, a_2 等系数的微调程度来标记, 等价地也可由临界指数 p_0 的取值来标记.

不过, 对 $\tanh$ 和 $\sin$ 之类的奇激活函数, 会出现一个很好的结果. 由式 (5.86) 与 (5.88) 可知, 此时 $a_1 = b_1$; 若把普适类限制为奇激活函数, 就得到真正的临界指数 $p_\perp = 1$. 这意味着垂直扰动随 ℓ 衰减的幂次, 与中点核趋近固定点时的衰减幂次相同, 均为 $\sim 1/\ell$. 因此在临界性下, 比值 $K_{[2]}^{(\ell)}/K_{[0]}^{(\ell)}$ 在领头阶保持不变, 从而保留邻近垂直输入之间的夹角. 重要的是, 这保证了即便信号传播通过非常深的网络, 输入点之间的关系仍在 RG 流下得到保持.

此外, 垂直扰动较温和的衰减表明, 它们在某种意义上比平行扰动更重要. 原因是, 当深度足够大时, $K_{[1]}^{(\ell)}$ 分量会相对于 $K_{[0]}^{(\ell)}$ 与 $K_{[2]}^{(\ell)}$ 分量成为次领头项: 前者按 $1/\ell^2$ 标度, 而后两者按 $1/\ell$ 标度. 正因如此, 后文将忽略核的这些平行扰动.

5.3.4 半稳定普适类: SWISH 等与 GELU 等

在最后这个小节中, 我们考察另外两个颇为流行的激活函数, 以探索偏离零点的非平凡固定点 $K_{00}^* \neq 0$.




图 5.3: 对 SWISH 激活函数 (左) 和 GELU 激活函数 (右), 把条件 (5.73) 的左边绘成 K_{00}^* 的函数. 对这两个激活函数, 所绘曲线都在 $K_{00}^* = 0$ 处以及某个非零的半稳定非平凡固定点 $K_{00}^* \neq 0$ 处达到一 (黑点).

- SWISH 激活函数定义为

$$\sigma(z) = \frac{z}{1 + e^{-z}}. \quad (5.100)$$

与对 softplus 的直觉类似, SWISH 旨在成为 ReLU 的光滑版本. 按照第 5.3.1 节中寻找临界初始化超参数的一般算法, 实际上可为核找到两个非平凡固定点, 见图 5.3. 具体而言, 条件 (5.73) 在 $K_{00}^* = 0$ 、 $(C_b, C_W) = (0, 4)$ 处成立, 也在 $K_{00}^* \approx 14.32017362$ 且

$$(C_b, C_W) \approx (0.55514317, 1.98800468). \quad (5.101)$$

时成立. 对 $K_{00}^* = 0$ 的非平凡固定点, 可以验证 $(-a_1) < 0$, 因而它是不稳定的.

对 $K_{00}^* \approx 14.3$ 的非平凡固定点, 把中点核递推展开为 $K_{00}^{(\ell)} = K_{00}^* + \Delta K_{00}^{(\ell)}$, 得到

$$\Delta K_{00}^{(\ell+1)} = \Delta K_{00}^{(\ell)} + \tilde{a}_1 \left(\Delta K_{00}^{(\ell)} \right)^2 + O\left(\left(\Delta K_{00}^{(\ell)} \right)^3 \right), \quad (5.102)$$

其中 $(-\tilde{a}_1) \approx -2.84979219 \cdot 10^{-6}$.

这里, 有限固定点附近的大 ℓ 渐近分析与 $K_{00}^* = 0$ 的情形完全相同, 结果为

$$\Delta K_{00}^{(\ell)} \sim \left[\frac{1}{(-\tilde{a}_1)} \right] \frac{1}{\ell}. \quad (5.103)$$

不过, 由于固定点值 $K_{00}^* \approx 14.3$ 非零, 解释略有不同. 具体而言, 这意味着当 $K_{00}^{(\ell)} < K_{00}^*$ 时, 核被固定点吸引; 而当 $K_{00}^{(\ell)} > K_{00}^*$ 时, 核受到排斥.⁸¹ 因此, 这个固定点是半稳定的 (half-stable), 于是该激活函数或许也只能算“半有用”. 不过在实践中, $|\tilde{a}_1|$ 足够小, 使得 SWISH 在 $K_{00}^{(\ell)} \sim K_{00}^* \approx 14.3$ 附近表现得近乎尺度不变.

- GELU 激活函数定义为

$$\sigma(z) = \frac{z}{2} \left[1 + \operatorname{erf} \left(\frac{z}{\sqrt{2}} \right) \right], \quad (5.104)$$

回忆一下, 它是另一个经过光滑化的 ReLU. 按照寻找临界性的方案, 条件 (5.73) 同样满足两次: 一次在 $K_{00}^* = 0$ 、 $(C_b, C_W) = (0, 4)$ 处, 另一次在 $K_{00}^* = (3 + \sqrt{17})/2$ 且

$$(C_b, C_W) \approx (0.17292239, 1.98305826), \quad (5.105)$$

时, 见图 5.3. 与 SWISH 类似, $K_{00}^* = 0$ 处的固定点不稳定, 其中 $(-a_1) = -6/\pi < 0$; 而 $K_{00}^* = (3 + \sqrt{17})/2$ 处的固定点是半稳定的, 在此情形有 $(-\tilde{a}_1) \approx (1.43626419) \cdot 10^{-4}$. 注意, 此处 $\tilde{a}_1$ 的符号与 SWISH 情形中的符号不同. 因而这一次, 当 $K_{00}^{(\ell)} > K_{00}^*$ 时, 中点核被固定点吸引; 当 $K_{00}^{(\ell)} < K_{00}^*$ 时, 它受到排斥.⁸² 注意, GELU 的 $|\tilde{a}_1|$ 比 SWISH 更大, 这意味着它的尺度不变程度更低, 也更不像 ReLU.

平移后的 softplus 只在 $K_{00}^* = 0$ 处容许一个不稳定的非平凡固定点; 与之不同, 这里 GELU 与 SWISH 激活函数的非单调性在 $K_{00}^* \neq 0$ 处产生了半稳定非平凡固定点. 两者都是半稳定普适类 (half-stable universality class) 的代表. 对这两个类似于 ReLU 的激活函数, $K_{00}^* \neq 0$ 半稳定非平凡固定点的临界初始化超参数, 都与 ReLU 的临界初始化 $(C_b, C_W) = (0, 2)$ 非常相似; 各类中的激活函数确实只是对 ReLU 的小扰动. 与此同时, 在特定核值 $K_{00}^* \neq 0$ 处存在固定点, 表明引入了一个特定尺度——无论这种引入多么微弱. 由此可以看出, 这些普适类破坏了尺度不变性.

总而言之, 尽管 SWISH 和 GELU 都类似于 ReLU 且同样光滑, 但它们都不如 ReLU 本身. 如果想使用光滑激活函数, 请使用 tanh.

⁸¹使用 SWISH 的半临界初始化超参数 (5.101) 时, 在 $K_{00}^* \approx 14.5$ 处还有一个平凡固定点; 当 $K_{00}^{(\ell)} > 14.3$ 时, 它以指数方式吸引中点核.

⁸²使用 GELU 的半临界初始化超参数 (5.105) 时, 在 $K_{00}^* \approx 3.2$ 处还有一个平凡固定点; 当 $K_{00}^{(\ell)} < (3 + \sqrt{17})/2 \approx 3.6$ 时, 它以指数方式吸引中点核.

5.4 涨落

现在，我们已经完全理解如何把无限宽网络调谐到临界性，接下来要离开这个大 n 极限，分析现实网络的行为。具体而言，我们将把第 3.3 节针对深度线性网络所作的有限宽分析，推广到具有非线性激活函数的 MLP。在正式开始之前，先回顾开展这项分析的动机。

第一，注意实践者通常只使用单个网络，而非网络系综。⁸³ 如前所述，在某些情况下，单次实例化一般会偏离均值。因此，要理解所关心可观测量在单次实例化中典型地会发生什么，不仅必须计算均值，还必须计算不同实例化之间相对于均值的涨落。正如第 3.3 节所解释的，这类涨落通常是有限宽效应，由受 $1/n$ 抑制的四点顶点 $V_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell)}$ 控制。如果涨落很大，那么即使单次实例化是从调谐到临界性的初始化分布中抽取的，其表现也可能很差。

第二，第 4.3 节已经看到，无限宽网络第 ℓ 层的预激活分布因子化为

$$p(z_1^{(\ell)}, \dots, z_{n_\ell}^{(\ell)} | \mathcal{D}) = p(z_1^{(\ell)} | \mathcal{D}) \cdots p(z_{n_\ell}^{(\ell)} | \mathcal{D}) + O\left(\frac{1}{n_\ell}\right), \quad (5.106)$$

其中每个神经元上的分布 $p(z_i^{(\ell)} | \mathcal{D})$ 都是统计独立的高斯分布。（为强调这里对神经元的依赖，我们显式写出了神经元指标，同时省略了样本指标）。回忆第 1.3 节关于相互作用与统计独立性的讨论，这意味着神经元之间的层内相关完全是有限宽现象。后文将说明，这种相互作用的缺失如何联系到如下事实：无限宽网络的表征无法在基于梯度的学习过程中演化。因而，理解这些有限宽效应，是理解实际网络如何从输入数据中真正学到东西的先决条件。⁸⁴

第三，有限宽修正可以改变可观测量的均值。如第 4.5 节所见，原则上，有限宽下所有可观测量都会收到无穷级数的次领头修正。例如，度量可能的有限宽 NLO 修正 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ ，可以移动无限宽度量 $G_{\alpha_1\alpha_2}^{\{0\}(\ell)} \equiv K_{\alpha_1\alpha_2}^{(\ell)}$ ，亦即核。这种有限宽修正有可能破坏临界性，因为临界初始化超参数的推导显式依赖于核的无限宽固定点值。⁸⁵

本节将得到两个主要结论。

- 第一，我们将发现，领头的有限宽涨落按照网络的深宽比 L/n 标度。第 3.3 节已经看到，这个涌现尺度对 `linear` 激活函数十分重要；这里将看到，它对非线性激活函数也极为普遍地存在。用第 4.6 节的语言说，这意味着有限宽修正在表征群流下是相关的，而更深的网络会越来越偏离简单的无限宽极限。这突显了分析此类网络时纳入这些修正的重要性；同时，考虑到过深网络会遭受压倒性的涨落，这还表明，我们的微扰有效理论在实际网络同样表现最佳的区间内最为适用。
- 第二，只要对 C_W 作适当的 $O(1/n)$ 修正，NLO 度量 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 就相对于核 $K_{\alpha_1\alpha_2}^{(\ell)}$ 是次领头的。这意味着在插值极限—— $n, L \rightarrow \infty$ 且 L/n 固定——中，NLO 度量消失，因此对大多数深度适中的宽网络，可以安全地忽略它。

⁸³实际上，在某些情形下实践者也可以使用网络系综，不过这类模型的计算成本会与系综中的网络数成正比增长。

⁸⁴第 6 节将更详细地讨论这些相关性在 MLP 归纳偏置中的作用，随后在第 11 节把这些相互作用联系到表征学习。

⁸⁵第 5.4.1 节将说明，对尺度不变普适类，NLO 度量 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)} = 0$ ；这正是我们在第 3 节讨论深度线性网络时没有考察这类修正的原因。

单输入，再探

为说明有限宽度所产生的重要定性效应，我们再次专门考察单个输入. 选择单输入的原因，最好通过另一个包含两项的列表来理解：

- (i) 一旦利用核的单输入与双输入分析，在领头阶把两个初始化超参数 C_b 和 C_W 调谐到临界性，唯一额外的调谐便来自 NLO 度量 $G_{\alpha_1\alpha_2}^{\{1\}(\ell)}$ 的单输入分析. 因此，顶点和 NLO 度量的多输入解不会为临界性分析增添任何内容.
- (ii) 双输入顶点最值得关注的部分，是给出网络输入-输出雅可比矩阵方差的一个分量. (正如脚注 70 所述，该雅可比矩阵的均值由核的 $K_{[2]}^{(\ell)}$ 分量刻画.) 不过，对这个输入-输出方差原本要作的分析，将包含在第 8 节对神经切向核方差的分析之中；后者更直接地给出与训练相关的梯度方差.

在本节余下部分，我们将省略 $\alpha = 0$ 的样本指标，因为只考察单个输入时，这种记号没有必要而且十分累赘. 我们还进一步简化，令所有隐藏层的宽度相等：

$$n_1 = n_2 = \cdots = n_{L-1} \equiv n. \quad (5.107)$$

这不仅是一个合理的选择，而且在记号上意味着无须处处携带 $n_\ell/n_{\ell-1}$ 因子. 在这些约定下，第 4 节中的相关递推变为

$$K^{(\ell+1)} = C_b + C_W g(K^{(\ell)}), \quad (5.108)$$

$$V^{(\ell+1)} = \chi_{\parallel}^2(K^{(\ell)}) V^{(\ell)} + C_W^2 \left[\langle \sigma^4(z) \rangle_{K^{(\ell)}} - \langle \sigma^2(z) \rangle_{K^{(\ell)}}^2 \right], \quad (5.109)$$

$$G^{\{1\}(\ell+1)} = \chi_{\parallel}(K^{(\ell)}) G^{\{1\}(\ell)} + \frac{1}{8} j(K^{(\ell)}) \frac{V^{(\ell)}}{(K^{(\ell)})^2}. \quad (5.110)$$

其中，辅助函数 $g(K)$ 和平行磁化率 $\chi_{\parallel}(K)$ 分别定义于式 (5.5) 和 (5.50)，而我们还定义了另一个辅助函数

$$j(K) \equiv C_W \left\langle \sigma(z) \sigma(z) \left[\left(\frac{z^2}{K} \right)^2 - 6 \left(\frac{z^2}{K} \right) + 3 \right] \right\rangle_K. \quad (5.111)$$

通过仿照第 5.2 节和第 5.3 节中对 $K_{00}^{(\ell)}$ 、 $\delta K_{[1]}^{(\ell)}$ 、 $\delta \delta K_{[2]}^{(\ell)}$ 所作的自举分析，可以对每个普适类求解这三个递推关系.

5.4.1 尺度不变普适类的涨落

回忆第 5.2 节，尺度不变普适类包含形如

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0, \end{cases} \quad (5.112)$$

的任意激活函数，其中可把 ReLU ($a_+ = 1, a_- = 0$) 作为典型代表. 还要回忆，对这一类，我们已求得辅助函数 $g(K) = A_2 K$ ，平行易感率 $\chi_{\parallel} = A_2 C_W \equiv \chi$ ，其中依赖激活函

数的常数为 $A_2 \equiv (a_+^2 + a_-^2)/2$. 新递推式 (5.109) 和 (5.110) 中的其余项, 也可通过计算半直线上的高斯积分来求得:

$$C_W^2 \left[\langle \sigma^4(z) \rangle_K - \langle \sigma^2(z) \rangle_K^2 \right] = C_W^2 (3A_4 - A_2^2) K^2, \quad j(K) = 0, \quad (5.113)$$

这里引入新的依赖激活函数的常数

$$A_4 \equiv \frac{a_+^4 + a_-^4}{2}, \quad (5.114)$$

与另一个常数 A_2 配对. 利用这些表达式, 三个递推关系可简化为

$$K^{(\ell+1)} = C_b + \chi K^{(\ell)}, \quad (5.115)$$

$$V^{(\ell+1)} = \chi^2 \left(\frac{3A_4}{A_2^2} - 1 \right) (K^{(\ell)})^2 + \chi^2 V^{(\ell)}, \quad (5.116)$$

$$G^{\{1\}(\ell+1)} = \chi G^{\{1\}(\ell)}. \quad (5.117)$$

提醒一下, 我们已经在第 5.2 节求解了核递推.

现在情形相当简单.

- 第一, 回忆第 4.1 节, 第一层预激活分布总是严格高斯的, 这意味着对 n 的所有阶, 第一层二点关联函数都可直接由第一层核 $K^{(1)}$ 给出:

$$\mathbb{E} \left[z_i^{(1)} z_j^{(1)} \right] = \delta_{ij} K^{(1)}. \quad (5.118)$$

因此, 第一层 NLO 度量必定为零, 即 $G^{\{1\}(1)} = 0$; 递推式 (5.117) 随即表明, NLO 度量在之后的每一层也都为零. 由此可知, 对尺度不变普适类中的激活函数, 单输入度量不会得到 $O(1/n)$ 修正.

- 第二, 令 $C_b = 0$ 、 $C_W = 1/A_2$, 聚焦于临界性. 如第 5.2 节所述, 这组超参数把核固定为依赖输入但与层无关的常数

$$K^{(\ell)} = K^* \equiv \frac{1}{A_2} \left(\frac{1}{n_0} \sum_{i=1}^{n_0} x_i^2 \right). \quad (5.119)$$

特别地, 这意味着单输入核的临界指数为 $p_0 = 0$. 令 $\chi = 1$, 并把上式代入式 (5.116), 得到四点顶点的线性增长解

$$V^{(\ell)} = (\ell - 1) \left(\frac{3A_4}{A_2^2} - 1 \right) (K^*)^2. \quad (5.120)$$

由此可直接读出尺度不变普适类的另一个临界指数: 若假设 $V^{(\ell)} \sim (1/\ell)^{p_V}$, 则 $p_V = -1$. 这个指数编码了顶点在 RG 流下的线性增长. 尤其值得注意的是, 式 (5.120) 前的系数 $(3A_4/A_2^2 - 1)$, 对 **linear** 激活函数等于 2, 而对 **ReLU** 激活函数则等于 5. 显然, **ReLU** 网络中的涨落显著强于深度线性网络. 更一般地说, 这类涨落的强度并不具有普适性.

- 第三, 再来考察半临界性: 令 $C_W = 1/A_2$, 但把偏置方差取为任意正常数 $C_b > 0$. 正如第 5.2 节所见, 此时核朝无穷远处的非平凡固定点线性增长, 即 $K^{(\ell)} \sim \ell$, 也就是 $p_0 = -1$. 把这样的解代入顶点递推式 (5.116), 可见四点顶点按三次方增长, $V^{(\ell)} \sim \ell^3$, 即 $p_V = -3$. 然而, 适当的无量纲量——用核的平方归一化顶点——仍随 ℓ 线性增长, 即 $p_V - 2p_0 = -1$.⁸⁶ 因此, 即使在半临界性下, 有限宽修正的普适 ℓ/n 标度仍然保持.

5.4.2 $K^* = 0$ 普适类的涨落

现在来考察 $K^* = 0$ 普适类. 提醒一下, 这一类包含所有满足 $\sigma(0) = 0$ 且 $\sigma'(0) \neq 0$ 的光滑激活函数, 可以把 $\tanh$ 作为典型代表. 在第 5.3.3 节中, 我们确定了这一类激活函数在 $K^* = 0$ 处具有非平凡固定点, 并求得相应的临界初始化超参数为 $C_b = 0$ 和 $C_W = 1/\sigma_1^2$. 本小节余下部分将聚焦于处在临界性的这类网络.

仿照第 5.3.3 节中求解核递推的做法, 我们可以在 $z = 0$ 附近对激活函数作 Taylor 展开, 并显式计算高斯积分, 从而求出顶点递推式 (5.109) 和 NLO 度量递推式 (5.110) 中的高斯期望. 牢记临界性条件 $C_W = 1/\sigma_1^2$, 得到

$$\chi_{\parallel}(K) = 1 + 2a_1 K + 3a_2 K^2 + O(K^3), \quad (5.121)$$

$$C_W^2 \left[\langle \sigma^4(z) \rangle_K - \langle \sigma^2(z) \rangle_K^2 \right] = 2K^2 + (-52a_1 + 60b_1) K^3 + O(K^4), \quad (5.122)$$

$$\frac{j(K)}{8K^2} = a_1 + 3a_2 K + O(K^2). \quad (5.123)$$

这里, $\chi_{\parallel}(K)$ 的表达式只是从第 5.3.3 节重新列出. 同样, 为减少来回翻阅, 我们也重新列出原先在式 (5.94) 中给出的核扰动的大 ℓ 渐近展开:

$$\begin{aligned} \Delta K^{(\ell)} = & \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \left[\frac{-(a_2 - a_1^2)}{a_1^3} \right] \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell^2} \\ & + \left[\frac{-(a_2 - a_1^2)^2}{a_1^5} \right] \frac{\left[\log\left(\frac{\ell}{\ell_0}\right) \right]^2}{\ell^3} + \left[\frac{(a_2 - a_1^2)^2}{a_1^5} \right] \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell^3} + O\left(\frac{1}{\ell^3}\right). \end{aligned} \quad (5.124)$$

四点顶点

现在来求解四点顶点. 把式 (5.121) 和 (5.122) 代入单输入顶点递推式 (5.109), 得到代数方程

$$\begin{aligned} V^{(\ell+1)} = & V^{(\ell)} \left[1 + 4a_1 \Delta K^{(\ell)} + (6a_2 + 4a_1^2) (\Delta K^{(\ell)})^2 + \dots \right] \\ & + 2 (\Delta K^{(\ell)})^2 + (-52a_1 + 60b_1) (\Delta K^{(\ell)})^3 + \dots \end{aligned} \quad (5.125)$$

对大 ℓ 渐近展开使用标度拟设 (5.93):

$$V^{(\ell)} = \left(\frac{1}{\ell} \right)^{p_V} \left[\# + \# \frac{\log \ell}{\ell} + \frac{\#''}{\ell} + \dots \right], \quad (5.126)$$

⁸⁶再稍作说明, 请先重读第 1.3 节脚注 16 中关于量纲分析的内容. 现在, 若赋予预激活量纲 $[z] = \zeta$, 则核的量纲为 $[K] = \zeta^2$, 而四点顶点的量纲为 $[V] = \zeta^4$. 因此, 比值 V/K^2 是无量纲的.

再对 $\Delta K^{(\ell)}$ 使用式 (5.124), 并匹配各项, 得到

$$V^{(\ell)} = \left[\frac{2}{3a_1^2} \right] \frac{1}{\ell} + \left[\frac{2(a_2 - a_1^2)}{3a_1^4} \right] \frac{\log\left(\frac{\ell}{\ell_0}\right)}{\ell^2} + \left[\frac{5a_2 + a_1(82a_1 - 90b_1)}{3a_1^4} \right] \frac{1}{\ell^2} + O\left(\frac{\log^2(\ell)}{\ell^3}\right). \quad (5.127)$$

这里的常数尺度 ℓ_0 与紧邻上方的 $\Delta K^{(\ell)}$ 展开中的尺度相同, 它再次承载了解的数据依赖性. 还可以读出控制 $K^* = 0$ 普适类顶点渐近衰减的临界指数: $p_V = 1$.

注意, 这里的指数 $p_V = 1$ 和四点顶点行为 $V^{(\ell)} \sim 1/\ell$, 不同于尺度不变普适类中的 $p_V = -1$ 以及相应行为 $V^{(\ell)} \sim \ell$. 还要注意, 对 $K^* = 0$ 类和尺度不变类, 我们也分别在核的行为中看到了 $p_0 = 1$ 与 $p_0 = 0$ 的差别. 然而, 若转而考察无量纲量

$$\frac{V^{(\ell)}}{n(K^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_V - 2p_0} + \dots, \quad (5.128)$$

就会看到, 它在两类激活函数中的标度一致:

$$p_V - 2p_0 = -1. \quad (5.129)$$

因此, 这条**标度律**跨越不同的普适类成立. 由于归一化量 (5.128) 控制可观测量的领头有限宽修正——第 3.3 节对此作了详细讨论——这条定律意味着, 这些修正在表征群流下总是相关的.

具体而言, 对尺度不变普适类, 归一化顶点函数为

$$\frac{V^{(\ell)}}{n(K^{(\ell)})^2} = \left(\frac{3A_4}{A_2^2} - 1 \right) \frac{\ell}{n} + O\left(\frac{1}{n}\right), \quad (5.130)$$

而对 $K^* = 0$ 普适类, 则为

$$\frac{V^{(\ell)}}{n(K^{(\ell)})^2} = \left(\frac{2}{3} \right) \frac{\ell}{n} + O\left(\frac{\log(\ell)}{n}\right). \quad (5.131)$$

这在实践中的含义是, 深度和宽度相同的 ReLU 网络与 tanh 网络, 对这类修正的敏感程度大体相近. 不过, 这个量的 $O(1)$ 系数确实依赖于具体激活函数: 对 ReLU 为 5, 对 tanh 为 2/3. 在附录 A 中, 我们将借助信息论工具进一步分析这一点, 并看到它如何使不同激活函数偏好不同的纵横比 L/n .

裸 NLO 度量

接下来求解 NLO 度量递推式 (5.110). 把式 (5.121) 中的 $\chi_{\parallel}(K)$ 和式 (5.123) 中的 $j(K)$ 代入, 得到

$$G^{\{1\}(\ell+1)} = G^{\{1\}(\ell)} [1 + 2a_1 \Delta K^{(\ell)} + \dots] + V^{(\ell)} [a_1 + 3a_2 \Delta K^{(\ell)} + \dots]. \quad (5.132)$$

按照现在已经熟悉的做法, 假设大 ℓ 下有标度拟设

$$G^{\{1\}(\ell)} = \# \left(\frac{1}{\ell} \right)^{p_1} + \dots, \quad (5.133)$$

其中 p_1 是相应的临界指数. 对式 (5.132) 作自举: 把先前的解—— $\Delta K^{(\ell)}$ 的式 (5.124) 与 $V^{(\ell)}$ 的式 (5.127)——代入, 再插入 $G^{\{1\}(\ell)}$ 的拟设 (5.133) 并匹配各项, 得到

$$G^{\{1\}(\ell)} = - \left[\frac{1}{3(-a_1)} \right] + O\left(\frac{\log(\ell)}{\ell}\right). \quad (5.134)$$

这个解要求取 $p_1 = 0$, 并给出一个不随 ℓ 变化的领头贡献. 把它与核结合, 可见有限宽修正后的二点关联函数

$$\mathbb{E} \left[z_i^{(\ell)} z_j^{(\ell)} \right] = \delta_{ij} \left[K^{(\ell)} + \frac{1}{n} G^{\{1\}(\ell)} + O(1/n^2) \right], \quad (5.135)$$

中的组合为

$$K^{(\ell)} + \frac{1}{n} G^{\{1\}(\ell)} = \left[\frac{1}{(-a_1)} \right] \left(\frac{1}{\ell} - \frac{1}{3n} \right) + \dots \quad (5.136)$$

这与尺度不变普适类形成对照; 在后者中, NLO 度量恒等于零.

对于 NLO 度量, 适当的无量纲量是二点关联函数 (5.135) 中修正项与无限宽项之比:

$$\frac{1}{n} \frac{G^{\{1\}(\ell)}}{K^{(\ell)}} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_1 - p_0} + \dots, \quad (5.137)$$

指数 $p_1 - p_0$ 控制这个 NLO 修正的相对重要性. 此处 $p_1 - p_0 = -1$, 意味着上述比值按深宽比 ℓ/n 标度. 这再次展示了我们的有效理论的微扰截断 $\ell \lesssim n$. 不过, 正如下文将看到的, 在这个特定情形中, 这种标度其实是在有限宽度下恰当地调谐初始化超参数 C_W 所造成的假象.

重整化 NLO 度量

在第 5.3.3 节中, 我们学会了如何求 $K^* = 0$ 普适类的临界初始化超参数, 即利用核分量的无限宽递推来固定超参数 C_b 和 C_W . 然而, 第 4.5 节已经解释过, 大 n 展开中计算的所有可观测量都会收到 $1/n$ 的无穷级数次领头修正. 这表明, 在临界性下, 我们本应允许进一步精调初始化超参数, 即考虑大 n 展开

$$C_b^{(\ell)} = c_b^{(\ell)\{0\}} + \frac{c_b^{(\ell)\{1\}}}{n_{\ell-1}} + \frac{c_b^{(\ell)\{2\}}}{n_{\ell-1}^2} + \dots, \quad (5.138)$$

$$C_W^{(\ell)} = c_W^{(\ell)\{0\}} + \frac{c_W^{(\ell)\{1\}}}{n_{\ell-1}} + \frac{c_W^{(\ell)\{2\}}}{n_{\ell-1}^2} + \dots, \quad (5.139)$$

从而可以逐阶调节这些超参数. 这种展开可能在微扰理论的每一阶给出额外的临界性条件.

考察有限宽递推式 (5.109) 和 (5.110) 可知, 这类次领头调谐不会影响依赖四点顶点的可观测量的领头阶结果, 因为这些可观测量的领头贡献本身已经是 $O(1/n)$. 不过, 这些调谐确实会影响 NLO 度量的解, 因为 NLO 度量本身就是次领头的.

具体而言, 把展开式 (5.138) 和 (5.139) 代入核递推式 (5.108), 会给 NLO 度量递推式 (5.110) 带来额外贡献. 与 $c_b^{(\ell)\{1\}}$ 或 $c_W^{(\ell)\{1\}}$ 成正比的项现在是次领头的, 因而会对

NLO 度量递推作出贡献：

$$G^{\{1\}(\ell+1)} = \left[c_b^{(\ell)\{1\}} + c_W^{(\ell)\{1\}} g(K^{(\ell)}) \right] + \chi_{\parallel}^{(\ell)} G^{\{1\}(\ell)} + \frac{1}{8} j(K^{(\ell)}) \frac{V^{(\ell)}}{(K^{(\ell)})^2}. \quad (5.140)$$

从这个新的“重整化”视角来看，上一子小节中的“裸”分析，只是选择了特定的次领头修正 $c_b^{(\ell)\{1\}} = c_W^{(\ell)\{1\}} = 0$ 。更一般地，在这个次领头阶，我们确实还有额外的旋钮可调。

把式 (5.121) 中的 $\chi_{\parallel}(K)$ 、式 (5.123) 中的 $j(K)$ 和式 (5.83) 中的 $g(K)$ 代入，得到代数方程

$$G^{\{1\}(\ell+1)} = c_b^{(\ell)\{1\}} + c_W^{(\ell)\{1\}} \sigma_1^2 \left[K^{(\ell)} + a_1 (K^{(\ell)})^2 + \dots \right] + G^{\{1\}(\ell)} \left[1 + 2a_1 K^{(\ell)} + \dots \right] + V^{(\ell)} \left[a_1 + 3a_2 K^{(\ell)} + \dots \right]. \quad (5.141)$$

把核的解 (5.124) 和顶点的解 (5.127) 代入——务必保留二者关于 ℓ 的次领头项——再插入 $G^{\{1\}(\ell)}$ 的大 ℓ 标度拟设 (5.133) 并匹配各项，可知调谐

$$c_b^{(\ell)\{1\}} = 0, \quad c_W^{(\ell)\{1\}} = \frac{2}{3} c_W^{(\ell)\{0\}} = \frac{2}{3\sigma_1^2}, \quad (5.142)$$

会使 NLO 度量的解在渐近意义下受到抑制：

$$G^{\{1\}(\ell)} = \frac{2}{3} \left[\frac{3a_2 - a_1^2}{(-a_1)^3} \right] \frac{1}{\ell} + O\left(\frac{\log(\ell)}{\ell^2}\right), \quad (5.143)$$

其临界指数为 $p_1 = 1$ 。具体而言，对 $c_b^{(\ell)\{1\}}$ 的调谐是为了抑制一个按 $\sim \ell$ 线性增长的贡献，而对 $c_W^{(\ell)\{1\}}$ 的调谐则抵消了此前在式 (5.134) 中得到的常数 $O(1)$ 部分。

- 从一种意义上说，我们先前的裸分析颇为幸运：若不作 $c_b^{(\ell)\{1\}} = 0$ 的调谐而重新分析，无量纲比值 (5.137) 将随深度二次增长，并意味着 NLO 度量在 $\ell \sim \sqrt{n}$ 时支配核。这个次领头修正在达到有效理论的 ℓ/n 微扰截断之前就变得参数上很大，真正的含义是它正在指数增长； $c_b^{(\ell)\{1\}} \neq 0$ 最终会破坏临界性。
- 从另一种意义上说，我们先前又颇为不幸：若没有 $c_W^{(\ell)\{1\}} = \frac{2}{3} c_W^{(\ell)\{0\}}$ 的调谐，NLO 度量就是一个领头的 ℓ/n 修正。现在可以看到，正确处理后有 $p_1 - p_0 = 0$ ，且无量纲比值 (5.137) 在领头阶关于深度为 $O(1)$ 。这类修正在 RG 流下称为边缘的。这意味着，尽管我们始终必须考虑相关的四点顶点修正，但只要遵守有限宽调谐 (5.142)，就应当可以忽略 NLO 度量修正。

最后，临界初始化超参数必须包含这类微扰修正，这为实践中网络深度 L 接近网络宽度 n 时可能出现的问题提供了另一种视角。即使对这类网络的系综，为了使描述系综的有效理论达到临界性，平均量也需要愈来愈精细的调谐，例如式 (5.138) 和 (5.139)。对任何合理的 n ，这些修正很快就会精细到超过表示超参数时使用的浮点精度极限。因此在实践中，基本不可能把这样的大型方形网络调谐到临界性。⁸⁷

⁸⁷注意，这与第 3.4 节针对深度线性网络所描述的大深度混沌行为是完全不同的问题。对尺度不变普适类，NLO 度量修正为零，因而 $c_W^{(\ell)\{1\}} = 0$ 。

5.5 尺度不变普适类的有限夹角分析

本节将直面尺度不变普适类激活函数中的一个重要微妙之处。

回忆一下，这一类激活函数具有形式

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0, \end{cases} \quad (5.144)$$

并且通常在原点 $z = 0$ 处有一个折点（唯一例外是退化成员 `linear` 激活函数，此时 $a_+ = a_-$ ）。在给出核的 δ 展开式 (5.22)–(5.24) 后，我们最早在脚注 66 中提到这个微妙问题，并轻微质疑了这些展开对非光滑 $\sigma(z)$ 的有效性。随后在脚注 72 中，我们描述了这个微妙问题的主要后果。具体而言，我们声称：对非线性尺度不变激活函数，在临界性下，垂直扰动 $\delta\delta K_{[2]}^{(\ell)}$ 关于层数保持常数，是微扰 δ 展开的假象。要正确理解这一说法，需要为这一类激活函数推导完整的非微扰核递推。这样又能看清前述核分量 $\delta\delta K_{[2]}^{(\ell)}$ 在大 ℓ 下渐近行为的修正。

在这项分析中，只需关注两个范数相同的输入 $x_{i;\pm}$ 。在先前的设定中，我们假设两个输入彼此接近，使其差 $\delta x_i \equiv (x_{i;+} - x_{i;-})$ 在微扰意义下很小，即 $\delta x_i \ll 1$ ；这里不对它们的差作任何假设。由网络演化的对称性，与这两个输入对应的两个预激活量各自的范数也相等：

$$K_d^{(\ell)} \equiv \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;+}^{(\ell)} \right)^2 \right] = \mathbb{E} \left[\frac{1}{n_\ell} \sum_{i=1}^{n_\ell} \left(z_{i;-}^{(\ell)} \right)^2 \right]. \quad (5.145)$$

从几何上看，这意味着两个预激活量共同位于半径为 $\sqrt{n_\ell K_d^{(\ell)}}$ 的 n_ℓ 维球面上；从代数上看，这意味着平行分量为零，即 $K_{[1]}^{(\ell)} = 0$ ，参见式 (5.18)。下文把 $K_d^{(\ell)}$ 称为**对角核**。⁸⁸

余下的动力学变量是两个预激活量之间的极角。因此，可以用如下参数化分解双输入核矩阵：

$$K_{\alpha_1 \alpha_2}^{(\ell)} = \begin{pmatrix} K_{++}^{(\ell)} & K_{+-}^{(\ell)} \\ K_{-+}^{(\ell)} & K_{--}^{(\ell)} \end{pmatrix} = K_d^{(\ell)} \begin{pmatrix} 1 & \cos(\psi^{(\ell)}) \\ \cos(\psi^{(\ell)}) & 1 \end{pmatrix}, \quad \psi^{(\ell)} \in [0, \pi]. \quad (5.146)$$

极角 $\psi^{(\ell)}$ 从 0 变化到 π ：在 0 处，预激活量重合，即 $z_{i;+} = z_{i;-}$ ，使核矩阵退化；在 π 处，它们反相关，即 $z_{i;+} = -z_{i;-}$ 。到目前为止，我们只固定了两个输入的范数相等，并按照一种特定坐标选择分解了核；这种选择和参数化可用于任意激活函数的分析。下面专门考察尺度不变激活函数，因为对这一类可以推导极角的非微扰递推。

极角的 RG 流

对角核满足现在已经熟悉的单输入核递推式 (5.4)：

$$K_d^{(\ell+1)} = C_b + C_W g(K_d^{(\ell)}) = C_b + A_2 C_W K_d^{(\ell)}, \quad (5.147)$$

⁸⁸在微扰意义下，对角核 $K_d^{(\ell)}$ 在 δ 展开的领头阶等于中点核 $K_{00}^{(\ell)}$ ——即中点输入 $x_{i;0} \equiv (x_{i;+} + x_{i;-})/2$ 的核——参见式 (5.22)–(5.24)。在非微扰意义下，这两个核却非常不同。要最鲜明地看出这一点，考虑两个对径输入 $x_{i;+} = -x_{i;-}$ 。此时中点输入是零向量 $x_{i;0} = 0$ ，第一层中点核为 $K_{00}^{(1)} = C_b^{(1)}$ 。相比之下，对角核由 $K_d^{(1)} = C_b^{(1)} + (C_W^{(1)}/n_0) \sum_{i=1}^{n_0} x_{i;\pm}^2$ 中任一符号给出。

其中右边代入了尺度不变普适类的具体结果 (5.63), 并回忆 $A_2 \equiv (a_+^2 + a_-^2)/2$. 这部分分析直接继承自第 5.2 节. 回忆一下, 对任意初始化超参数都很容易求解这个递推; 特别地, 取 $C_b = 0$ 和 $A_2 C_W = 1$ 即达到临界性, 此时对角核严格保持常数: $K_d^{(\ell)} = K_d^{(1)} \equiv K_d^*$.

确定了大小的演化后, 现在要求极角 $\psi^{(\ell)}$ 的递推. 把新分解 (5.146) 代入完整核递推式 (5.1), 递推的非对角分量变为

$$K_d^{(\ell+1)} \cos(\psi^{(\ell+1)}) = C_b + C_W \langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}}. \quad (5.148)$$

在这种参数化下, 高斯期望为

$$\langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}} \equiv \frac{\int dz_+ dz_- \sigma(z_+) \sigma(z_-) e^{-\frac{1}{2} \sum_{\alpha_1, \alpha_2 = \pm} K_{(\ell)}^{\alpha_1 \alpha_2} z_{\alpha_1} z_{\alpha_2}}}{2\pi K_d^{(\ell)} \sin(\psi^{(\ell)})}, \quad (5.149)$$

其中分母来自计算行列式 $\sqrt{|2\pi K^{(\ell)}|}$. 为了继续推进, 需要求出这个棘手的积分.

在处理一般情形之前, 先聚焦于 ReLU. 令 $a_+ = 1$, $a_- = 0$, 可见当 $z_+ > 0$ 且 $z_- > 0$ 时, 高斯期望的被平均量为 $\sigma(z_+) \sigma(z_-) = z_+ z_-$, 其他区域则为零. 因此, 高斯期望 (5.149) 完全集中在第一象限. 此外, 注意被积函数在宇称变换 $(z_+, z_-) \rightarrow (-z_+, -z_-)$ 下不变, 于是可以巧妙地把第一象限上的积分换成第一与第三象限上积分的一半. 这样, 上述高斯期望可改写为

$$\langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}} = \frac{\frac{1}{2} \int dz_+ dz_- \Big|_{z_+ z_- > 0} z_+ z_- e^{-\frac{1}{2} \sum_{\alpha_1, \alpha_2 = \pm} K_{(\ell)}^{\alpha_1 \alpha_2} z_{\alpha_1} z_{\alpha_2}}}{2\pi K_d^{(\ell)} \sin(\psi^{(\ell)})}. \quad (5.150)$$

事实证明, 上式是整个推导中唯一巧妙的一步; 其余部分只是一串艰巨的坐标变换.

这一串变换包含三次坐标变换:

$$\begin{aligned} z_{\pm} &= \frac{u \pm w}{\sqrt{2}} \\ &= \sqrt{\frac{K_d^{(\ell)} [1 + \cos(\psi^{(\ell)})]}{2}} x \pm \sqrt{\frac{K_d^{(\ell)} [1 - \cos(\psi^{(\ell)})]}{2}} y \\ &= \sqrt{\frac{K_d^{(\ell)} [1 + \cos(\psi^{(\ell)})]}{2}} r \cos(\phi) \pm \sqrt{\frac{K_d^{(\ell)} [1 - \cos(\psi^{(\ell)})]}{2}} r \sin(\phi). \end{aligned} \quad (5.151)$$

第一次变换把核对角化, 使分布因子化为 $p(z_+, z_-) = p(u)p(w)$; 第二次利用核的本征值归一化坐标; 最后一次把笛卡尔坐标换成极坐标.⁸⁹ 相应地, 式 (5.150) 指数中的和可改写为

$$\sum_{\alpha_1, \alpha_2 = \pm} K_{(\ell)}^{\alpha_1 \alpha_2} z_{\alpha_1} z_{\alpha_2} = \frac{u^2}{K_d^{(\ell)} [1 + \cos(\psi^{(\ell)})]} + \frac{w^2}{K_d^{(\ell)} [1 - \cos(\psi^{(\ell)})]} = x^2 + y^2 = r^2, \quad (5.152)$$

⁸⁹与式 (5.33) 和 (5.34) 中的微扰计算不同, 这里的对角化和归一化在非微扰意义下是严格的. 再深入想一下: 尽管总可以按照式 (5.151) 变换坐标, 但从式 (5.149) 过渡到式 (5.150) 时, 我们使用了 ReLU 的具体性质, 从而既确定了受限积分域, 又在该区域内把被积函数简化为 $\sigma(z_+) \sigma(z_-) \rightarrow z_+ z_-$. 对一般激活函数, 新坐标下由式 (5.151) 得到的积分仍然难以计算; 为了继续推进, 只能对 $\psi^{(\ell)}$ 作微扰展开, 而这最终与 δ 展开类似.

而被积函数中的乘积变为

$$z_+ z_- = \frac{K_d^{(\ell)} r^2}{2} [\cos(2\phi) + \cos(\psi^{(\ell)})] , \quad (5.153)$$

积分测度则变换为

$$dz_+ dz_- = K_d^{(\ell)} \sin(\psi^{(\ell)}) r dr d\phi . \quad (5.154)$$

把式 (5.152)–(5.154) 代回高斯期望 (5.150), 得到

$$\langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}} = \frac{K_d^{(\ell)}}{8\pi} \left[\int_0^\infty dr r^3 e^{-\frac{r^2}{2}} \right] \int_0^{2\pi} d\phi \Big|_{\cos(2\phi) + \cos(\psi^{(\ell)}) > 0} [\cos(2\phi) + \cos(\psi^{(\ell)})] . \quad (5.155)$$

余下部分相对直接. 再作坐标变换 $s = r^2/2$, 便可求出径向积分:

$$\int_0^\infty dr r^3 e^{-\frac{r^2}{2}} = \int_0^\infty ds 2s e^{-s} = \left[-2e^{-s} - 2s e^{-s} \right]_0^\infty = 2 . \quad (5.156)$$

对于角向积分, 注意 $\cos(2\phi)$ 的任意函数在四个区间 $\tilde{\phi} \equiv 2\phi \in [0, \pi]$ 、 $[\pi, 2\pi]$ 、 $[2\pi, 3\pi]$ 和 $[3\pi, 4\pi]$ 上给出相同贡献. 此外, 在第一个区间内, 约束 $\cos(\tilde{\phi}) > -\cos(\psi^{(\ell)})$ 可简单写成 $\tilde{\phi} < \pi - \psi^{(\ell)}$. 合起来便有

$$\begin{aligned} & \int_0^{2\pi} d\phi \Big|_{\cos(2\phi) + \cos(\psi^{(\ell)}) > 0} [\cos(2\phi) + \cos(\psi^{(\ell)})] \\ &= 4 \int_0^\pi \frac{d\tilde{\phi}}{2} \Big|_{\cos(\tilde{\phi}) + \cos(\psi^{(\ell)}) > 0} [\cos(\tilde{\phi}) + \cos(\psi^{(\ell)})] \\ &= 2 \int_0^{\pi - \psi^{(\ell)}} d\tilde{\phi} [\cos(\tilde{\phi}) + \cos(\psi^{(\ell)})] = 2 \sin(\psi^{(\ell)}) + 2(\pi - \psi^{(\ell)}) \cos(\psi^{(\ell)}) . \end{aligned} \quad (5.157)$$

把式 (5.156) 和 (5.157) 代入式 (5.155), 最终得到 ReLU 激活的高斯期望:

$$\langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}} = \frac{K_d^{(\ell)}}{2\pi} [\sin(\psi^{(\ell)}) + (\pi - \psi^{(\ell)}) \cos(\psi^{(\ell)})] . \quad (5.158)$$

现在来求任意尺度不变激活函数 (5.144) 的棘手积分 (5.149). 一般而言, 第一象限的贡献与 a_+^2 成正比, 第三象限也有与 a_-^2 成正比的类似贡献; 经过前面的巧妙变换, 两种情形的约束都是 $z_+ z_- > 0$. 第二和第四象限还各有与 $a_+ a_-$ 成正比的贡献, 并满足约束 $z_+ z_- < 0$. 遵循与先前 ReLU 情形非常相似的一系列步骤, 可以把高斯期望 (5.149) 求为

$$\begin{aligned} \langle \sigma(z_+) \sigma(z_-) \rangle_{K^{(\ell)}} &= \frac{K_d^{(\ell)}}{2\pi} (a_+^2 + a_-^2) \int_0^{\pi - \psi^{(\ell)}} d\tilde{\phi} [\cos(\tilde{\phi}) + \cos(\psi^{(\ell)})] \\ &\quad + \frac{K_d^{(\ell)}}{2\pi} (2a_+ a_-) \int_{\pi - \psi^{(\ell)}}^\pi d\tilde{\phi} [\cos(\tilde{\phi}) + \cos(\psi^{(\ell)})] \\ &= \frac{K_d^{(\ell)}}{2\pi} (a_+ - a_-)^2 [\sin(\psi^{(\ell)}) - \psi^{(\ell)} \cos(\psi^{(\ell)})] \\ &\quad + \left(\frac{a_+^2 + a_-^2}{2} \right) K_d^{(\ell)} \cos(\psi^{(\ell)}) . \end{aligned} \quad (5.159)$$

因此, 核非对角部分的完整非微扰递推 (5.148) 为

$$\begin{aligned} & K_d^{(\ell+1)} \cos(\psi^{(\ell+1)}) \\ &= C_b + C_W \left\{ \frac{K_d^{(\ell)}}{2\pi} (a_+ - a_-)^2 [\sin(\psi^{(\ell)}) - \psi^{(\ell)} \cos(\psi^{(\ell)})] + \left(\frac{a_+^2 + a_-^2}{2} \right) K_d^{(\ell)} \cos(\psi^{(\ell)}) \right\}. \end{aligned} \quad (5.160)$$

这里可以注意到, 尽管已经求出了高斯期望, 递推关于 $\psi^{(\ell+1)}$ 仍然高度非线性.

趁你还在这里、注意力也仍然集中, 我们再记录尺度不变普适类的另一个非微扰高斯期望: $\langle \sigma'(z_+) \sigma'(z_-) \rangle_{K^{(\ell)}}$. 这个积分比上面的未求导积分简单得多, 因为在每个象限内, 被平均量 $\sigma'(z_+) \sigma'(z_-)$ 都是常数. 其余步骤与上面相同, 得到

$$\begin{aligned} \langle \sigma'(z_+) \sigma'(z_-) \rangle_{K^{(\ell)}} &= \frac{a_+^2 + a_-^2}{4\pi} \left[\int_0^\infty dr r e^{-\frac{r^2}{2}} \right] \int_0^{2\pi} d\phi \Big|_{\cos(2\phi) + \cos(\psi^{(\ell)}) > 0} \\ &\quad + \frac{2a_+ a_-}{4\pi} \left[\int_0^\infty dr r e^{-\frac{r^2}{2}} \right] \int_0^{2\pi} d\phi \Big|_{\cos(2\phi) + \cos(\psi^{(\ell)}) < 0} \\ &= \left(\frac{a_+^2 + a_-^2}{2} \right) - \frac{\psi^{(\ell)}}{2\pi} (a_+ - a_-)^2. \end{aligned} \quad (5.161)$$

看来你们还没准备好接受这个结果. 不过未来的你们会爱上它.⁹⁰

极角的临界性分析

既然已经求出了递推, 现在就调到临界性, 并确定极角 $\psi^{(\ell)}$ 在大 ℓ 下的正确渐近行为. 在尺度不变临界性上, $C_b = 0$ 、 $A_2 C_W = 1$, 且对角核恒为 $K_d^{(\ell)} = K_d^*$; 于是非对角递推 (5.160) 化为极角的解耦递推:

$$\cos(\psi^{(\ell+1)}) = \cos(\psi^{(\ell)}) + \rho [\sin(\psi^{(\ell)}) - \psi^{(\ell)} \cos(\psi^{(\ell)})]. \quad (5.162)$$

这里引入新常数

$$\rho \equiv \frac{1}{\pi} \frac{(a_+ - a_-)^2}{(a_+^2 + a_-^2)}, \quad (5.163)$$

会很方便; 它概括了具体尺度不变激活函数的全部细节. 粗略地说, ρ 是激活函数在原点处折点程度的无量纲度量: 对 **linear** 激活函数它等于零, 对 **ReLU** 则等于 $1/\pi$. 立刻可以看出, 当且仅当 $\rho = 0$ 时, 极角才被严格保持. 特别地, 我们在第 3.2 节看到的 **linear** 激活函数对完整双输入核矩阵的保持, 并不适用于这个普适类的任何其他成员.

为了确定极角 $\psi^{(\ell)}$ 的大 ℓ 行为, 需要有办法分析递推 (5.162). 正如我们反复强调的, 分析这类非线性递推的主要工具是先找出固定点, 再在其附近线性化.⁹¹ 直接观察递推可知, $\psi^* = 0$ 是一个固定点. 因此, 应当聚焦于小角度区域: $\psi^{(\ell)} \ll 1$.

在零极角附近对递推 (5.162) 中的三角函数作 Taylor 展开, 线性化递推变为

$$\psi^{(\ell+1)} = \psi^{(\ell)} \sqrt{1 - \frac{2\rho}{3} \psi^{(\ell)} + O(\psi^2)} = \psi^{(\ell)} - \frac{\rho}{3} (\psi^{(\ell)})^2 + O(\psi^3). \quad (5.164)$$

⁹⁰当我们在第 10.3 节研究尺度不变普适类在无限宽度下的泛化误差时, 这个结果会非常有用.

⁹¹我们已经非微扰地求出了高斯期望 (5.159), 并完整计入了激活函数的不光滑性, 其中常数 ρ (5.163) 刻画了它的折点程度, 因此现在采用微扰展开是完全安全的.

为求解这个递推，可以使用标度拟设 (5.93)；在这里它写成

$$\psi^{(\ell)} = \left(\frac{1}{\ell}\right)^{p_\psi} \left[c_{0,0} + O\left(\frac{\log \ell}{\ell}\right) \right], \quad (5.165)$$

其中临界指数 p_ψ 控制极角的衰减。将该拟设代入递推 (5.164)，并匹配等式两边的各阶项，得到解

$$\psi^{(\ell)} = \left(\frac{3}{\rho}\right) \frac{1}{\ell} + O\left(\frac{\log \ell}{\ell^2}\right). \quad (5.166)$$

由此读出临界指数 $p_\psi = 1$ ；除退化的 $\rho = 0$ 的 linear 极限外，它是普适的，而在该退化极限中有 $p_\psi = 0$ 。

为了用本章其余部分的语言重述这个结果，先利用 (5.20) 将双输入核 (5.146) 投影到 $\gamma_{\alpha\beta}^{[a]}$ 表示，再代入 (5.166)：

$$K_{[0]}^{(\ell)} = K_d^{(\ell)} \left[\frac{1 + \cos(\psi^{(\ell)})}{2} \right] = K_d^* + O\left(\frac{1}{\ell^2}\right), \quad (5.167)$$

$$K_{[2]}^{(\ell)} = K_d^{(\ell)} \left[\frac{1 - \cos(\psi^{(\ell)})}{2} \right] = K_d^* \left(\frac{9}{4\rho^2}\right) \frac{1}{\ell^2} + O\left(\frac{\log \ell}{\ell^3}\right). \quad (5.168)$$

这些解正是前面脚注 72 中所作断言的基础。特别地，垂直扰动 $K_{[2]}^{(\ell)}$ 会从小深度 $\ell \ll \ell_{\text{cross}}$ 时的近似常数行为，交叉过渡到大深度 $\ell \gg \ell_{\text{cross}}$ 时的幂律衰减 $\sim 1/\ell^2$ 。⁹² 这意味着尺度不变垂直扰动的真正临界指数是 $p_\perp = 2$ 。

这里的交叉尺度 ℓ_{cross} 近似为

$$\ell_{\text{cross}} \sim \frac{3}{\rho\psi^{(\ell=1)}} \sim \frac{3}{2\rho} \sqrt{\frac{K_{[0]}^{(\ell=1)}}{K_{[2]}^{(\ell=1)}}}. \quad (5.169)$$

这个结果来自把由第一层条件确定的小深度常数解，与 (5.166) 给出的大 ℓ 渐近解相等；在 (5.169) 的右端，还利用 (5.167) 和 (5.168) 将极角 $\psi^{(\ell=1)}$ 写成了核分量。可见，初始角 $\psi^{(\ell=1)}$ 越小——也就是两个输入彼此越接近——朴素垂直递推 (5.65) 原先给出的常数解就能维持得越久，幂律区域也越晚开始起作用。

上面的讨论解释了为何 δ 展开看不到这一交叉过渡：在这种分析中，依照构造， $K_{[2]}^{(\ell=1)}$ 是无穷小的。这意味着交叉尺度 (5.169) 被推到无穷远，因而微扰理论无法看见它。还可以换一种方式理解。当两个输入的间隔很小时，可将角度改写为

$$\psi^{(\ell)} \approx 2\sqrt{\frac{\delta\delta K_{[2]}^{(\ell)}}{K_d^*}} + \dots, \quad (5.170)$$

于是，将角度递推 (5.164) 平方并重新整理各项，可将其改写成

$$\delta\delta K_{[2]}^{(\ell+1)} = \delta\delta K_{[2]}^{(\ell)} - \frac{4\rho}{3\sqrt{K_d^*}} \left(\delta\delta K_{[2]}^{(\ell)}\right)^{\frac{3}{2}} + \dots. \quad (5.171)$$

⁹²对于 $\rho = 0$ 的深线性网络，解 (5.168) 是退化的，并不适用。不过根据紧接在前面的讨论可知，对于这种网络，极角在任意深度都保持不变。

遗憾的是, Taylor 展开不可能产生这样的非整数幂 $3/2$. 结合垂直扰动 $K_{[2]}^{(\ell)}$ 的拟设 (5.24), 这就解释了为何此前看不到这个修正项. (对于光滑激活函数不存在这个问题; 在 $K^* = 0$ 普适类中, 我们可以完全信赖 Taylor 展开及其后的分析.)

这里的总体教训是: 每当遇到奇异的高斯期望时, 都必须非常小心. 今后需要考虑非线性尺度不变激活函数的多个输入时, 我们会记得这里的结果.

第 6 章

贝叶斯学习

...概率论的数学规则并非仅仅是计算“随机变量”频率的规则；它们也是进行任何种类推断（即可信推理）的唯一规则，而我们将为此以最一般的形式运用这些规则。

E. T. Jaynes, 阐释其著作 [50] 的主题。

在前三章中，我们花费了相当多的时空来分析初始化时宽神经网络的系综。特别是，通过 $1/n$ 展开和深度渐近分析，我们已经相当透彻地理解了架构、宽度、深度与初始化超参数之间的相互作用；正是它们共同规定了预激活量的有效分布。

在这项研究中，我们极其仔细地关注了深度学习中的深度，却完全忽略了学习。但这是一本深度学习之书，而不只是一本深奥之书。因此，本章将开始学习“学习”；而且——如果章标题确实能够反映内容——在本书余下各章中，我们还会继续学习“学习”。

我们的学习之旅将从讨论贝叶斯推断开始，因为它为一般性地思考学习提供了自然框架。首先，我们将在 §6.1 中解释贝叶斯概率观：概率被重新解释为，在不同假设下我们对世界所持信念的强度。我们将在那里看到，贝叶斯推断的规则——其实就是扩展到概率推理的逻辑规则——给出了一种逻辑自洽的方式，把新观测到的信息纳入代表各项假设的概率模型。

从 §6.2 开始，我们将看到，这一简单却强大的框架为何能让我们分析并理解深度神经网络如何从观测数据中学习。

在 §6.2.1 中，我们将详细说明贝叶斯模型拟合如何用于神经网络。首先，我们把已经充分研究过的有效预激活量分布重新解释为先验分布，它编码在观察任何数据之前我们对模型输出的初始信念。以此为起点，贝叶斯推断的规则随即蕴含一种学习算法，用来收紧我们的信念，使之尽可能拟合观测。推断所得的后验分布还允许我们对输出尚未观测、但需要推断的新输入作出贝叶斯预测。这自然过渡到实际实现：先讨论近似方法——从贝叶斯角度解释本章之后若干“轮次”中要探讨的基于梯度的学习方法——再讨论本章余下部分所依据的一种精确方法。

在 §6.2.2 中，我们将拓展视野，思考关于生命、宇宙以及一切的终极问题：贝叶斯模型比较。我们将解释如何使用贝叶斯证据，在由不同超参数和网络架构选择所组织的若干合理假设之间进行选择，从而挑出最佳者。贝叶斯模型比较还为研究归纳偏置提供了定量工具；这种偏置正是深度学习模型中常被隐藏的假设。作为额外收获，我们还会

看到，把贝叶斯推断规则用于这种模型比较时，如何自动纳入奥卡姆剃刀。借助这些工具，我们便真正可以开始回答本书开篇提出的一个基本问题：为什么有些神经网络模型表现如此出色，而另一些却会失败？

这些抽象讨论之后，是分别在 §6.3 和 §6.4 中对无限宽与有限宽神经网络的一系列具体计算。

其中一些计算会强化上一章的主题。首先，我们将证明贝叶斯模型比较偏好临界初始化超参数，从而为临界性原理提供进一步证据 (§6.3.1)。我们还会说明有限宽相互作用的另一种作用。具体而言，相关涨落的累积会诱导出偏好神经关联的归纳偏置，从而产生 Hebb 学习的倾向；这是一条受生物神经元启发的学习原理 (§6.4.1)。

另一些计算则对比了使用精确贝叶斯学习训练的无限宽与有限宽模型在性质上的定性差异。分析网络输出的后验分布时，我们会看到，不同输出分量之间的相关只在有限宽时非零 (§6.3.2 ⊥ §6.4.2)。所得表达式也将清楚表明，精确贝叶斯学习虽在理论上很容易处理，却为何对任何具有合理规模的数据集都不切实际。接着，通过分析隐藏层表征的后验分布，我们会看到无限宽时表征学习缺失，而有限宽时表征学习存在 (§6.3.3 ⊥ §6.4.3)。总体上，这一对比将为以后考察由基于梯度的学习所训练的无限宽与有限宽模型提供有价值的蓝图 (§10 ⊥ §∞)。

6.1 贝叶斯概率

贝叶斯主义者总是从一个**假设** $\mathcal{H}$ 出发。在数学上，假设是一种机制，它为关于世界的陈述 A 指派数值 $p(A|\mathcal{H})$ 。这些陈述是逻辑命题，例如“明天会下雨”、“这幅图像 x 中有一只猫”，或“函数 $f(x)$ 在输入 x 上的输出值为 z ”；而数值 $p(A|\mathcal{H})$ 表示，根据假设 $\mathcal{H}$ 所概括的假定或世界模型，这些陈述的相对可信程度。在机器学习语境中， $p(A|\mathcal{H})$ 常称为**概率模型**。

正如这一记号和讨论所表明的，这些信念 $p(A|\mathcal{H})$ 是用概率的语言表达的。然而，对概率 $p(A|\mathcal{H})$ 的贝叶斯解释与我们在 §2.3 给出的系综解释有细微差别。它并不表示随机变量的统计量——即在条件 $\mathcal{H}$ 下观察到 A 的相对频率或机会——而是构成在假定 $\mathcal{H}$ 下我们对命题 A 的信念强度。⁹³ 进一步说，在这种贝叶斯视角下，整个概率论和统计推断都可作为对这些信念 $p(A|\mathcal{H})$ 所施加逻辑约束的结果而被唯一地导出。⁹⁴ 接下来我们将简要介绍这些约束，因为它们构成本章的基础；不过，本书到这里已经使用概率很久了，所以让我们尽量简洁。

形式上，第一个逻辑约束称为**乘法规则**

$$p(A, B|\mathcal{H}) = p(A|B, \mathcal{H}) p(B|\mathcal{H}) = p(B|A, \mathcal{H}) p(A|\mathcal{H}), \quad (6.1)$$

其中 $p(A, B|\mathcal{H})$ 表示在假设 $\mathcal{H}$ 下对 A 和 B 同时成立的联合信念，而 $p(A|B, \mathcal{H})$ 表示

⁹³与**贝叶斯概率**相对时，系综解释通常称为**频率主义概率**。本书会采用最适合所考察问题的解释：如果我们通过从初始化分布中随机抽取参数来实例化模型，分析一个系综是合理的；如果我们依据固定假设进行推断，或比较不同假设，则采用贝叶斯视角是合理的。

⁹⁴关于这一观点的详细展开，参见 Jaynes 的著作 [50]；我们这里的简短概述远不足以公允呈现其内容。

在已经观测到 B 的条件下, 根据 $\mathcal{H}$ 对 A 的条件信念. 第二个逻辑约束称为**求和规则**

$$p(A|\mathcal{H}) = \sum_B p(A, B|\mathcal{H}), \quad (6.2)$$

它把关于 A 和 B 的联合信念与仅关于 A 的边缘信念联系起来.⁹⁵ 这里, 符号 $\sum_B$ 表示对离散变量 B 的全部逻辑可能取值求和; 若 B 是连续变量, 则表示积分.⁹⁶ 特别地, 如果把在 $\mathcal{H}$ 下绝对确定成立的陈述 C 指派为 $p(C|\mathcal{H}) \equiv 1$, 则这一求和规则蕴含归一化条件

$$\sum_B p(B|\mathcal{H}) = \sum_B p(C, B|\mathcal{H}) = p(C|\mathcal{H}) = 1. \quad (6.3)$$

有了这些规则, 贝叶斯主义者在固定假设后, 会收集信息以修正不同信念的可信程度. 例如, 观察到 A 后, 我们可能希望更新关于 B 的信念. 这种**贝叶斯推断**可由以下事实完成: 对乘法规则 (6.1) 作代数重排, 就得到当附加信息 A 被纳入条件时信念应如何改变

$$p(B|A, \mathcal{H}) = \frac{p(A|B, \mathcal{H}) p(B|\mathcal{H})}{p(A|\mathcal{H})}. \quad (6.4)$$

这一重排重要到拥有自己的名称——**贝叶斯法则**——甚至方程中的每个因子也各有名称:

- 因子 $p(B|\mathcal{H})$ 称为 B 的**先验**, 因为它量化我们对 B 的先验信念; 也就是说, 它编码在观察任何附加信息之前, 完全依据模型 $\mathcal{H}$ 所形成的关于 B 的信念.
- 因子 $p(B|A, \mathcal{H})$ 称为给定 A 时 B 的**后验**, 因为它量化得知 A 后我们对 B 的后验信念; 也就是说, 它编码模型 $\mathcal{H}$ 在观察到 A 后如何更新关于 B 的信念.
- 因子 $p(A|B, \mathcal{H})$ 称为**似然**. 我们将在 §6.2.1 讨论模型拟合时进一步说明其名称与解释.
- 因子 $p(A|\mathcal{H})$ 称为 $\mathcal{H}$ 的**证据**. 我们将在 §6.2.2 讨论模型比较时进一步说明其名称与解释.

注意, 后验会自动归一化:

$$\sum_B p(B|A, \mathcal{H}) = \sum_B \frac{p(A|B, \mathcal{H}) p(B|\mathcal{H})}{p(A|\mathcal{H})} = \sum_B \frac{p(A, B|\mathcal{H})}{p(A|\mathcal{H})} = \frac{p(A|\mathcal{H})}{p(A|\mathcal{H})} = 1. \quad (6.5)$$

更重要的是, 贝叶斯法则是在作出观测后更新一组信念的唯一逻辑自洽方式.

⁹⁵在 §4.4 的边缘化规则中, 我们实际上已经把这一求和规则作为 (4.93) 讨论过.

⁹⁶如果你已经深入阅读至此, (按贝叶斯意义) 大概已经很清楚; 但由于我们无法 (按贝叶斯意义) 绝对确定, 还是说明一下信念系统 $p(A|\mathcal{H})$ 中陈述 A 的含义. 有时, 陈述代表一个固定逻辑命题, 例如 $A =$ “Schrödinger 的猫还活着”, 此时 $p(A|\mathcal{H})$ 编码这只猫存活的可信程度. 有时, 陈述代表一个二元变量, 例如 $B =$ “Schrödinger 的猫的生存状态”, 它在 {死亡, 存活} 中取值, 而 $p(B|\mathcal{H})$ 给出两个二元结果上的分布. 更一般地, 陈述可以代表实验的可观测结果 $\mathcal{O}$, 也就是可观测量; 此时 $p(\mathcal{O}|\mathcal{H})$ 编码我们对不同结果之可信程度的相对信念, 而这类可观测量可以具有离散或连续的取值谱. 对我们而言, 这类一般可观测量的重要例子包括模型参数 θ 和预激活量 $z^{(\ell)}$.

6.2 贝叶斯推断与神经网络

贝叶斯推断框架可用于构建、更新并推理关于世界的强大概率模型。现在来看如何把贝叶斯框架应用于深度学习：先讨论模型拟合 (§6.2.1)，再讨论模型比较 (§6.2.2)。

6.2.1 贝叶斯模型拟合

对于神经网络，最自然的起点是讨论模型参数 $\theta_\mu = \{b_i^{(\ell)}, W_{ij}^{(\ell)}\}$ 的先验分布 $p(\theta|\mathcal{H})$ 。这个先验使我们能够量化对模型参数具体取值的初始信念；正是这些取值确定了神经网络函数逼近器 $f(x; \theta)$ 。最常见的选择，是直接把系综的初始化分布

$$p(\theta|\mathcal{H}) \equiv \prod_{\ell=1}^L \left\{ \left[\prod_{i=1}^{n_\ell} p(b_i^{(\ell)}) \right] \left[\prod_{i=1}^{n_\ell} \prod_{j=1}^{n_{\ell-1}} p(W_{ij}^{(\ell)}) \right] \right\}, \quad (6.6)$$

重新解释为贝叶斯先验分布。回顾一下， $p(b_i^{(\ell)})$ 与 $p(W_{ij}^{(\ell)})$ 分别由 (2.21) 和 (2.22) 给出，它们是均值为零、方差分别为 $C_b^{(\ell)}$ 与 $C_W^{(\ell)}/n_{\ell-1}$ 的高斯分布。

从贝叶斯视角看，这些初始化超参数是该假设 $\mathcal{H}$ 的一部分。假设 $\mathcal{H}$ 还包含我们对架构的选择——MLP、CNN、transformer 等——以及该架构类别中的全部架构超参数；例如，对于 MLP，还需选择深度 L 、隐藏层宽度 n_ℓ 和激活函数 $\sigma(z)$ 。简言之， $\mathcal{H}$ 就代表 $\mathcal{H}$ yperparameters.⁹⁷

这里，我们取用了熟悉的对象——超参数和刻画潜在网络实现频率的初始化分布——并以贝叶斯方式把它们解释为假设 $\mathcal{H}$ 和先验分布 $p(\theta|\mathcal{H})$ ；后者刻画我们对模型参数取值的初始信念。另一个熟悉的对象，当然是我们在前三章中一直显式计算的第 ℓ 层预激活量分布。为赋予它贝叶斯解释，先用 $z_{\mathcal{D}}^{(\ell)} \equiv \{z_{i;\delta}^{(\ell)}\}$ 表示在某数据集 $\mathcal{D}$ 的输入 $x_{j;\delta} \in \mathcal{D}$ 上计算的第 ℓ 层预激活量集合。随后，第 ℓ 层预激活量上的先验分布可通过下式与模型参数上的先验分布联系起来

$$p(z_{\mathcal{D}}^{(\ell)}|\mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(z_{\mathcal{D}}^{(\ell)}, \theta|\mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(z_{\mathcal{D}}^{(\ell)}|\theta, \mathcal{H}) p(\theta|\mathcal{H}), \quad (6.7)$$

其中第一个等号使用求和规则 (6.2)，第二个等号使用乘法规则 (6.1)。这一先验量化我们对不同神经网络变量的初始信念。更具体地说，对隐藏层 ℓ ，该分布代表我们对输入的一种特定特征表示的信念；对输出层 L ，它代表我们对函数逼近 $f(x; \theta)$ 行为的初始信念。更一般地，对于任意神经网络可观测量 $\mathcal{O} = \mathcal{O}(\theta)$ ，我们的先验信念由下式确定

$$p(\mathcal{O}|\mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(\mathcal{O}|\theta, \mathcal{H}) p(\theta|\mathcal{H}). \quad (6.8)$$

⁹⁷严格来说，每当讨论初始化分布时，我们都应始终以 $C_b^{(\ell)}$ 、 $C_W^{(\ell)}$ 和 n_ℓ 为条件： $p(\theta) \rightarrow p(\theta|n_0, C_b^{(1)}, C_W^{(1)}, \dots, n_{L-1}, C_b^{(L)}, C_W^{(L)})$ 。幸而，为简化记号，我们此前一直把这种详细依赖关系留作隐含处理，今后也会如此。但是，为强调假设对贝叶斯推断的重要性，本章中我们 (i) 将一直显式保留对总假设 $\mathcal{H}$ 的条件依赖，直至 §6.3.1 结束，同时 (ii) 把数据集 $\mathcal{D}$ 的依赖移到预激活量的总下标中。一个具体例子是，下一段在 (6.7) 中定义的第 ℓ 层预激活量先验分布 $p(z_{\mathcal{D}}^{(\ell)}|\mathcal{H})$ ，等价于本章之外所记的 $p(z^{(\ell)}|\mathcal{D})$ 。

为更好说明这些形式表达式的含义，以网络输出 $z_{\mathcal{D}}^{(L)}$ 为可观测量. 那么，输出层的先验分布 $p(z_{\mathcal{D}}^{(L)}|\mathcal{H})$ ，即 (6.7)，与初始化系综诱导的输出分布 (2.35) 相同，当且仅当我们还把给定参数时输出的条件分布选为确定性的：

$$p(z_{\mathcal{D}}^{(L)}|\theta, \mathcal{H}) = \prod_{i=1}^{n_L} \prod_{\delta \in \mathcal{D}} \delta(z_{i;\delta}^{(L)} - f_i(x_{\delta}; \theta)). \quad (6.9)$$

这里， $f_i(x_{\delta}; \theta)$ 是以定义 MLP 的迭代方程 (2.5) 给出的网络输出表达式，而 $z_{i;\delta}^{(L)}$ 被解释为随机变量. 于是，网络输出的先验分布 $p(z_{\mathcal{D}}^{(L)}|\mathcal{H})$ 刻画的是：根据假设 $\mathcal{H}$ ，我们对于给定输入集合 $\mathcal{D}$ 的一组联合输出值所持的总体初始信念；而不再是模型参数不同实现之间，初始化输出值的相对频率. 尽管如此，在操作上，前几章建立的形式体系仍可直接用于计算这些信念.

重要的是，注意输出的确定性条件分布 (6.9) 是贝叶斯框架中假设的一部分：根据假设 $\mathcal{H}$ ，给定模型参数 θ ，输出确定就是函数 $f(x; \theta)$ 所计算的值. 另一种常见假设是不确定假设

$$p(z_{\mathcal{D}}^{(L)}|\theta, \mathcal{H}) = \prod_{i=1}^{n_L} \prod_{\delta \in \mathcal{D}} \left\{ \frac{1}{\sqrt{2\pi\sigma_{\varepsilon}^2}} \exp\left[-\frac{1}{2\sigma_{\varepsilon}^2} (z_{i;\delta}^{(L)} - f_i(x_{\delta}; \theta))^2\right] \right\}, \quad (6.10)$$

它在方差为零和绝对确定的极限 $\sigma_{\varepsilon}^2 \rightarrow 0$ 下退化为确定性假设 (6.9).⁹⁸

充分讨论先验后，接下来考察后验. 随着我们收集到更多关于期望函数 $f(x)$ 真实行为的信息 A ，应当更新关于 $f(x; \theta)$ 的概率模型信念. 为以逻辑自洽的方式纳入这些信息，应使用贝叶斯法则. 具体而言，为更新对模型参数的信念，贝叶斯法则 (6.4) 要求使用

$$p(\theta|A, \mathcal{H}) = \frac{p(A|\theta, \mathcal{H}) p(\theta|\mathcal{H})}{p(A|\mathcal{H})}. \quad (6.12)$$

这里，为求后验分布 $p(\theta|A, \mathcal{H})$ ，先验分布 $p(\theta|\mathcal{H})$ 乘以模型参数 θ 对观测 A 的似然 $p(A|\theta, \mathcal{H})$ ，再除以证据 $p(A|\mathcal{H})$. 因此，给定这样的模型参数后验分布，我们对任意神经网络可观测量 $\mathcal{O}$ 的信念，会从先验 $p(\mathcal{O}|\mathcal{H})$ (6.8) 转变为插入 A 后的后验

$$p(\mathcal{O}|A, \mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_{\mu} \right] p(\mathcal{O}|\theta, \mathcal{H}) p(\theta|A, \mathcal{H}). \quad (6.13)$$

⁹⁸这一假设等价于向网络输出注入均值为零、方差为 σ_{ε}^2 的随机噪声 ε_i . 这又等价于把末层偏置平移为 $b_i^{(L)} \rightarrow b_i^{(L)} + \varepsilon_i$ ，因而只需把末层偏置方差平移为 $C_b^{(L)} \rightarrow C_b^{(L)} + \sigma_{\varepsilon}^2$ ，即可轻易将其纳入分析. 但要记住， ε_i 与偏置 $b_i^{(L)}$ 是分离的，并且不属于可调模型参数 θ_{μ} ；相反，该噪声旨在体现我们观察模型输出时存在的内禀不确定性.

在继续之前，再介绍网络输出的另一种常见假设：对每个输入 x 定义类别假设

$$p(i|\theta, \mathcal{H}) \equiv \frac{\exp[f_i(x; \theta)]}{\sum_{j=1}^{n_L} \exp[f_j(x; \theta)]}. \quad (6.11)$$

这一分布有时也称为 *softmax*. 这里，我们不考虑 n_L 个输出数值 $z_i^{(L)}$ 上的连续分布，而考虑输出类别 i 上的离散分布，例如 *dog*、*cat* 或 *car*. 对这类分类任务，每个数 $p(i|\theta, \mathcal{H})$ 都量化我们对输入 x 属于类别 i 之可能性的信念. 从函数角度看，softmax 可视为 logistic 函数 (2.10) 的推广，因为它把实数向量映射为离散概率分布.

这两个方程 (6.12) 和 (6.13) 唯一确定了如何纳入新信息 A ，以改变我们对任意神经网络可观测量取值的信念。

对于函数逼近任务，这类信息通常来自某个包含观测输入–输出对的数据集 $\mathcal{A}$ ：

$$A \equiv \{(x_{j;\tilde{\alpha}}, y_{i;\tilde{\alpha}})\} |_{\tilde{\alpha} \in \mathcal{A}}. \quad (6.14)$$

这里，每个输入 $x_{j;\tilde{\alpha}} \in \mathcal{A}$ 都与从期望函数 $f(x)$ 记录的相应真实输出 $y_{i;\tilde{\alpha}} \equiv f_i(x_{\tilde{\alpha}})$ 配对。⁹⁹ 观察到真实值 $y_{\mathcal{A}} \equiv \{y_{i;\tilde{\alpha}}\}$ 后，似然与证据分别是输出的条件信念 $p(y_{\mathcal{A}}|\theta, \mathcal{H})$ 与信念 $p(y_{\mathcal{A}}|\mathcal{H})$ 。这些信念在考察输出先验分布时已经出现，即取 (6.7) 中 $\ell = L$ ；不过现在它们要在与给定输入 $x_{\mathcal{A}}$ 对应的固定数值 $y_{\mathcal{A}}$ 上计算。

为直观理解其含义，再次采用确定性假设 (6.9)。此时似然为

$$p(A|\theta, \mathcal{H}) \equiv p(y_{\mathcal{A}}|\theta, \mathcal{H}) = \prod_{\tilde{\alpha} \in \mathcal{A}} \prod_{i=1}^{n_L} \delta(y_{i;\tilde{\alpha}} - f_i(x_{\tilde{\alpha}}; \theta)). \quad (6.15)$$

该似然十分明确地把模型参数限制为那些精确满足约束 $f_i(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 、因而拟合观测的参数。反之，集合中不满足这些约束的函数会被完全排除在后验分布之外，被判定为不似然。注意刚才发生了什么。朴素地说， $p(y_{\mathcal{A}}|\theta, \mathcal{H})$ 表示把模型参数设为 θ 时，我们对输出值 $y_{\mathcal{A}}$ 的信念。然而这里，我们先观察真实输出值 $y_{\mathcal{A}}$ ，再把 $p(y_{\mathcal{A}}|\theta, \mathcal{H})$ 解释为模型参数 θ 拟合观测 A 的可能程度。这就是“似然”一名的来源，也说明为什么准确的说法是“模型参数 θ 对观测 A 的似然”。

为获得更多直观认识，通常引入**负对数似然** $\mathcal{L}_{\mathcal{A}}(\theta)$ ——或损失——这一似然的表示：

$$p(y_{\mathcal{A}}|\theta, \mathcal{H}) \equiv \exp[-\mathcal{L}_{\mathcal{A}}(\theta)]. \quad (6.16)$$

这里，把损失参数化为参数 θ 的函数，是为了强调它是参数的（负对数）似然。¹⁰⁰ 对不确定假设 (6.10)，负对数似然具有著名的均方误差形式，即 **MSE 损失**：

$$\mathcal{L}_{\text{MSE}}(\theta) = \sum_{\tilde{\alpha} \in \mathcal{A}} \left\{ \frac{1}{2\sigma_{\varepsilon}^2} [f_i(x_{\tilde{\alpha}}; \theta) - y_{i;\tilde{\alpha}}]^2 + \frac{1}{2} \log(2\pi\sigma_{\varepsilon}^2) \right\}. \quad (6.17)$$

特别地，网络输出 $f_i(x_{\tilde{\alpha}}; \theta)$ 越接近目标值 $y_{i;\tilde{\alpha}}$ ，MSE 损失越小，而似然越大。¹⁰¹ 因此，损失自然衡量模型逼近函数真实行为的好坏。此外，由于损失 (6.17) 包含对观测的显式求和，随着观测到的输入–输出对数量 $N_{\mathcal{A}}$ 增加，似然可以压倒先验；换言之，只要收集了足够信息，最终我们先前的信念可以完全被从观测中学到的内容取代。

⁹⁹为最大限度避免歧义，本章将使用形如 $\tilde{\alpha}$ 的样本指标——即上方带波浪号的希腊字母 alpha——表示数据集 $\mathcal{A}$ 中那些其真实输出 $f(x)$ 已被观测的输入–输出对。

¹⁰⁰从函数逼近视角看，似然函数——因而损失——被视为辅助量；但从贝叶斯推断视角看，似然的形式是该假设的一部分，比较确定性假设 (6.9) 与不确定假设 (6.10)。

¹⁰¹在确定性极限 $\sigma_{\varepsilon}^2 \rightarrow 0$ 下，对于不能精确满足全部约束 $f_i(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 的函数，损失 $\mathcal{L}_{\mathcal{A}}(\theta)$ 将为正无穷；对于满足约束的函数则为负无穷。因而，不确定假设把 Dirac delta function 分布放宽为方差有限的高斯分布，从而软化了确定性假设的这种硬拟合约束。

当考察类别假设 (6.11) 时，softmax 分布的负对数似然给出交叉熵损失。我们将在 §10 中更系统地讨论选择不同损失函数的后果。

这就是**贝叶斯模型拟合**：把贝叶斯推断 (6.12) 用作提高函数逼近准确度的学习算法。它更偏好那些能更好拟合约束 $f_i(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 的函数，并惩罚不能拟合的函数。随后更新后验 (6.12)，使之反映“拟合观测”这一偏好与“遵守关于模型参数应取何值的先验信念”之间的平衡。

最终，我们希望用拟合后的贝叶斯模型作出**贝叶斯预测**。一般而抽象地说，这体现在 (6.13) 中。对函数逼近任务，更具体地说，我们最常关心的是关于网络输出 $\mathcal{O} = z^{(L)}$ 的后验信念，此时 (6.13) 写成

$$p(z^{(L)}|A, \mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_{\mu} \right] p(z^{(L)}|\theta, \mathcal{H}) p(\theta|A, \mathcal{H}). \quad (6.18)$$

一旦得到这一分布，就可以用其均值作为预测，并用方差表示置信程度。为计算其中任一量，无论采用何种方式，都需要对模型参数 θ 执行一个巨大的积分，才能正确加权不同信念。有鉴于此，下面将介绍两类处理模型边缘化的方法：(i) 基于鞍点近似的近似方法；(ii) 基于我们的有效理论方法的精确方法。

模型边缘化的近似方法：MAP 与 MLE

处理这种巨大积分的一种方式，是假定由后验分布 $p(\theta|A, \mathcal{H})$ (6.12) 给出的积分测度高度集中在其众数附近：

$$\theta_{\text{MAP}}^* \equiv \arg \max_{\theta} p(\theta|A, \mathcal{H}) = \arg \max_{\theta} [p(y_{\mathcal{A}}|\theta, \mathcal{H}) p(\theta|\mathcal{H})]. \quad (6.19)$$

这个最大值称为**最大后验** (MAP) 估计。完成这种最大化之后，可使用函数 $f(x; \theta_{\text{MAP}}^*)$ 执行任务；更一般地，还可由点估计 $\mathcal{O}(\theta_{\text{MAP}}^*)$ 近似完整后验分布 $p(\mathcal{O}|A, \mathcal{H})$ (6.12)。用随机变量的单个值近似概率分布，在统计学中称为点估计，在物理学中称为鞍点近似。另一个常用鞍点由似然的最大值给出

$$\theta_{\text{MLE}}^* \equiv \arg \max_{\theta} p(y_{\mathcal{A}}|\theta, \mathcal{H}), \quad (6.20)$$

它称为模型参数的**最大似然估计** (MLE)。

用负对数似然 $\mathcal{L}_{\mathcal{A}}(\theta)$ 表示时，MLE 等价于最小化损失

$$\theta_{\text{MLE}}^* = \arg \min_{\theta} \mathcal{L}_{\mathcal{A}}(\theta), \quad (6.21)$$

而 MAP 估计 (6.19) 则联合最小化损失与先验的负对数

$$\theta_{\text{MAP}}^* = \arg \min_{\theta} [\mathcal{L}_{\mathcal{A}}(\theta) - \log p(\theta|\mathcal{H})]. \quad (6.22)$$

特别地，对一般形式 $p(\theta|\mathcal{H}) \propto \exp(-\sum_{\mu=1}^P a_{\mu} \theta_{\mu}^2)$ 的高斯先验，负对数先验充当 $\sum_{\mu=1}^P a_{\mu} \theta_{\mu}^2$ 形式的正则化项，其作用是惩罚幅值很大的参数。损失随数据集 $\mathcal{A}$ 的大小广延增长，而正则化项保持不变，因此作出足够多观测后，我们朴素地预期先验最终会被似然压倒，MAP 与 MLE 估计将变得相似。

若要把这些近似方法用于宽神经网络，需要注意若干事项。¹⁰² 首先，最大似然估计 θ_{MLE}^* 实际上没有唯一的最优值，而是存在连续的一族最优值，因此仍需考虑它们之上的分布。重要的是，这种极大值分布关键依赖于获得极大值的方式，例如模型参数 θ_{init} 的初始化方式、用于估计极大值的学习算法——如梯度下降或随机梯度下降——以及控制学习算法的训练超参数。对这一最优值系综及其对初始化和训练超参数依赖的研究，大体将成为后续各章 §7–§∞ 的重点。¹⁰³

模型边缘化的精确方法：有效理论

对于先验 (6.7)，我们非常清楚，可以利用 $1/n$ 展开直接将模型参数积分掉。这种巨大边缘化正是 §4 的重点；写下 (6.7) 时，我们已经把初始化时的有效预激活量分布重新解释为关于预激活量的先验信念。对后验而言，唯一可能的担忧是需要执行完全不同的一组积分。下面将证明根本不需要。因此，在非常切实的意义上，贝叶斯推断中最艰苦的理论工作已经替我们完成了！

继续假定：对于 (6.14) 所定义子样本 $\mathcal{A}$ 中的一组给定输入 $x_{\mathcal{A}}$ ，我们观测了函数 $f(x)$ 的真实输出 $y_{i;\tilde{\alpha}} \equiv f_i(x_{\tilde{\alpha}})$ ，得到观测 A 。现在希望纳入这些观测所提供的信息，从而更新我们对另一子样本 $\mathcal{B}$ 中一组可能不同的输入 $x_{j;\tilde{\beta}} \in \mathcal{B}$ 的输出值 $z_{\mathcal{B}}^{(L)} \equiv \{z_{i;\tilde{\beta}}^{(L)}\}$ 的信念。¹⁰⁴ 从两个子样本之并集 $\mathcal{D} \equiv \mathcal{A} \cup \mathcal{B}$ 上网络输出的联合先验开始

$$p(z_{\mathcal{D}}^{(L)} | \mathcal{H}) \equiv p(z_{\mathcal{A}}^{(L)}, z_{\mathcal{B}}^{(L)} | \mathcal{H}), \quad (6.23)$$

令 $z_{\mathcal{A}}^{(L)} \rightarrow y_{\mathcal{A}}$ ，再用乘法规则 (6.1)，可使关于 $z_{\mathcal{B}}^{(L)}$ 的信念以已观测的真实值 $y_{\mathcal{A}}$ 为条件：

$$p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)} | \mathcal{H}) = p(z_{\mathcal{B}}^{(L)} | y_{\mathcal{A}}, \mathcal{H}) p(y_{\mathcal{A}} | \mathcal{H}). \quad (6.24)$$

随后，像 Thomas Bayes 牧师一样重排各项，得到

$$p(z_{\mathcal{B}}^{(L)} | y_{\mathcal{A}}, \mathcal{H}) = \frac{p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)} | \mathcal{H})}{p(y_{\mathcal{A}} | \mathcal{H})}. \quad (6.25)$$

贝叶斯法则的这一形式极其重要，所以让我们不厌其烦地澄清其解释。分母 $p(y_{\mathcal{A}} | \mathcal{H})$ 是给定子样本 $\mathcal{A}$ 中输入 $x_{\mathcal{A}}$ 时网络输出的先验，并在固定观测值 $y_{\mathcal{A}}$ 上求值，因而只是一

¹⁰²在 §10 中，我们会详细说明其全部工作方式。

¹⁰³由于后续各章会毫不留恋地放弃贝叶斯视角，这里不妨用新鲜的贝叶斯眼光解释这些不同方法。

在不纯贝叶斯方法——即 MLE——中，有初始化分布 $p(\theta_{\text{init}})$ ，却没有先验分布 $p(\theta | \mathcal{H})$ 。按构造，先验分布不进入不纯贝叶斯主义者的估计 (6.20)；但初始化分布 (2.21) 与 (2.22) 会进入其代码，给出作为优化与训练起点的具体网络实现。因而，初始化分布会诱导所得 MLE 估计上的分布。

在较不纯贝叶斯方法——即 MAP——中，初始化分布 $p(\theta_{\text{init}})$ 与先验分布 $p(\theta | \mathcal{H})$ 同时存在。对前者，仍用初始化分布 (2.21) 和 (2.22) 提供优化起点；对后者，通常使用高斯先验 $p(\theta | \mathcal{H}) \propto \exp(-\sum_{\mu=1}^P a_{\mu} \theta_{\mu}^2)$ ，它按 (6.22) 加到优化目标——损失——中时，充当正则化项。

在纯粹贝叶斯方法——本章余下部分的重点——中有先验分布 $p(\theta | \mathcal{H})$ ，却不需要初始化分布 $p(\theta_{\text{init}})$ 。纯粹贝叶斯主义者总是进行积分。在 (6.6) 中，我们真正做的是选择参数上的高斯先验，再对方差采用与初始化分布 (2.21) 和 (2.22) 相同的约定。本章余下部分将说明这样做为何合理。

¹⁰⁴为最大限度避免歧义，本章用形如 $\tilde{\beta}$ 的样本指标——即上方带点的希腊字母 beta——表示数据集 $\mathcal{B}$ 中那些其 $f(x)$ 输出值未被观测而需要推断的输入–输出对。

个数. 分子 $p(y_A, z_B^{(L)} | \mathcal{H})$ 是给定联合数据集 $\mathcal{D} \equiv \mathcal{A} \cup \mathcal{B}$ 中输入 x_D 时网络输出的先验, 它在固定观测值 y_A 上求值, 但网络输出 $z_B^{(L)}$ 仍然可变, 因而是 $z_B^{(L)}$ 的函数.¹⁰⁵ 分子与分母结合成左边的后验; 因此, 它是随机变量 $z_B^{(L)}$ 的函数, 编码我们对 $\mathcal{B}$ 中输入 x_B 的网络输出 $z_B^{(L)}$ 之可能取值的后验信念, 而该信念已由关于 $\mathcal{A}$ 中输入 x_A 的真实输出值 y_A 的观测所更新. 这样, 我们不必借助贝叶斯推断去学习模型参数, 以维持对灵活函数集内不同 $f(x; \theta)$ 的各种信念; 这里只需直接更新对函数 $f(x)$ 行为的信念.

在贝叶斯法则 (6.25) 的这种写法中, 从参数先验 (6.6) 过渡到预激活量先验 (6.7) 时, 已经完成了对全部模型参数的边缘化. 所得后验 (6.25) 实际上与显式边缘化模型参数后验分布——例如 (6.13)——所得结果完全等价. 为看出原因, 考察如下变换:

$$\begin{aligned}
 p(z_B^{(L)} | y_A, \mathcal{H}) &= \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(z_B^{(L)}, \theta | y_A, \mathcal{H}) = \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(z_B^{(L)} | \theta, \mathcal{H}) p(\theta | y_A, \mathcal{H}) \\
 &= \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(z_B^{(L)} | \theta, \mathcal{H}) \left[\frac{p(y_A | \theta, \mathcal{H}) p(\theta | \mathcal{H})}{p(y_A | \mathcal{H})} \right] \\
 &= \frac{1}{p(y_A | \mathcal{H})} \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(y_A, z_B^{(L)} | \theta, \mathcal{H}) p(\theta | \mathcal{H}) \\
 &= \frac{1}{p(y_A | \mathcal{H})} \int \left[\prod_{\mu=1}^P d\theta_\mu \right] p(y_A, z_B^{(L)}, \theta | \mathcal{H}) = \frac{p(y_A, z_B^{(L)} | \mathcal{H})}{p(y_A | \mathcal{H})}. \tag{6.27}
 \end{aligned}$$

唯一非平凡的一步是第三行, 在那里我们反向使用分解

$$p(z_A^{(L)}, z_B^{(L)} | \theta, \mathcal{H}) = p(z_A^{(L)} | \theta, \mathcal{H}) p(z_B^{(L)} | \theta, \mathcal{H}), \tag{6.28}$$

并取 $z_A^{(L)} \rightarrow y_A$. 该分解 (6.28) 表明, 给定参数时, 网络输出条件独立. 原因是, 对固定网络参数, 一个样例 $x_{\bar{\alpha}}$ 上的输出完全独立于任何其他样例 $x_{\bar{\beta}}$ 上的输出; 对于前述全部假设, 这显然成立. (否则, 神经网络在实践中就毫无用处.) 第二行方括号中对模型参数使用贝叶斯法则, 也清楚揭示了一方面的贝叶斯模型拟合 (6.12) 与另一方面的贝叶斯预测 (6.13) 之间的联系.

正如前面已经提到的, 这种模型边缘化的精确方法与理解神经网络的有效理论方法密切相关. 特别地, 虽然模型参数始终是神经网络定义的一部分, 但在确定网络输出分布的过程中, 我们总是必须把它们积分掉. 因此, 我们的深度学习有效理论始终直接处理参数初始化分布 (6.6) 所蕴含的完整网络函数系综, 而不是任何特定网络. 到目前为止, 我们借助典型性原理来说明这种系综方法的动机, 即用系综分析典型实现可能如何表现.¹⁰⁶ 这里的解释略有不同: 我们并不是试图让系综描述一个典型网络, 而是真正要

¹⁰⁵ 这里说“给定输入”, 是因为严格地说还应以 x_A 与 x_B 为条件. 具体而言, 在联合先验表达式

$$p(y_A, z_B^{(L)} | \mathcal{H}) \equiv p(y_A, z_B^{(L)} | x_D, \mathcal{H}), \tag{6.26}$$

中, y_A 固定而 $z_B^{(L)}$ 完全可变, 但完整输入集 $x_D \equiv x_A \cup x_B$ 决定参数化输出分布的数据依赖耦合 $g_{(L)}$ 与 $v_{(L)}$, 或等价地说, 决定度规 $G^{(L)}$ 与四点顶角 $V^{(L)}$. 后续各节将更详细地看到这一点.

¹⁰⁶ 从 §8 起, 我们将看到这一原理如何体现在由基于梯度的学习所训练的神经网络中.

考察完整潜在网络集合上的后验预测，并按照我们关于各预测可信程度的后验信念对每个网络加权。

在简短转向贝叶斯模型比较之后，§6.3 与 §6.4 的很大一部分重点，将分别是显式计算无限宽与有限宽 MLP 的这些贝叶斯预测 (6.25)。

6.2.2 贝叶斯模型比较

在贝叶斯模型拟合与贝叶斯预测中，证据 $p(y_A|\mathcal{H})$ 到目前为止基本没有发挥作用。对近似方法 MAP 与 MLE 及其相应最大化 (6.19) 和 (6.20) 而言，自变量的极大值严格独立于证据，因为证据不依赖模型参数。在贝叶斯预测的精确方法中，证据只是后验的归一化因子，我们很容易计算。

要真正看到证据发挥作用，亲爱的，你必须敢于把梦做得再大一点。也就是说，不要执着于单个假设 $\mathcal{H}$ ，而要考虑许多不同假设 $\mathcal{H}_a$ ，把它们都作为数据的可能解释。这就是**贝叶斯模型比较**的本质：用证据衡量不同概率模型作为全部观测之解释的可信程度。在深度学习语境中，这对应于比较对每个 $\mathcal{H}_a$ 所包含的不同建模选择——即不同超参数设定——所持的相对信念，并确定哪种建模选择最能描述观测 y_A 。

首先，再次使用贝叶斯法则——这一次用于证据——反转条件依赖：

$$p(\mathcal{H}_a|y_A) = \frac{p(y_A|\mathcal{H}_a)p(\mathcal{H}_a)}{p(y_A)}. \quad (6.29)$$

在这一形式中，左边的后验 $p(\mathcal{H}_a|y_A)$ 编码观察到 y_A 后，我们对不同假设 $\mathcal{H}_a$ ——不同超参数设定——之可信程度的更新信念；右边的先验 $p(\mathcal{H}_a)$ 编码我们关于这些假设的初始信念。有趣的是，贝叶斯模型拟合中假设 $\mathcal{H}_a$ 的旧证据 $p(y_A|\mathcal{H}_a)$ ，现在成为贝叶斯模型比较中假设 $\mathcal{H}_a$ 对观测 y_A 的新似然。最后，新证据 $p(y_A)$ 只是可以放心忽略的归一化因子。¹⁰⁷

为看清模型比较如何工作，用 (6.29) 比较两个不同假设 $\mathcal{H}_1$ 与 $\mathcal{H}_2$ ，判断哪一个更好地拟合观测。由于只有相对信念重要，取两个后验之比

$$\frac{p(\mathcal{H}_1|y_A)}{p(\mathcal{H}_2|y_A)} = \left[\frac{p(y_A|\mathcal{H}_1)}{p(y_A|\mathcal{H}_2)} \right] \frac{p(\mathcal{H}_1)}{p(\mathcal{H}_2)}, \quad (6.30)$$

可见无关的归一化因子 $p(y_A)$ 直接消去。方括号中的比值有时称为**贝叶斯因子**，它再乘以先验信念之比。特别地，贝叶斯因子包含全部观测依赖，并刻画给定新数据 y_A 后应如何更新对各假设的相对先验信念。比值大于一表示偏好假设 $\mathcal{H}_1$ 指定的模型，小于一则表示偏好假设 $\mathcal{H}_2$ 指定的模型。因而，旧证据——即新似然—— $p(y_A|\mathcal{H}_a)$ 的确可以非常有用。

¹⁰⁷当然，除非我们敢于把梦做得更大。如果真这样做——旁白：他们不会——就需要引入一个元假设 $\mathcal{G}$ ，编码关于不同超参数构型的先验信念 $p(\mathcal{H}_a|\mathcal{G})$ 。这有时称为贝叶斯层次建模。此时，用更宏大的证据 $p(y_A) \rightarrow p(y_A|\mathcal{G})$ 进行贝叶斯模型比较，原则上涉及对所有概率模型求和： $p(y_A|\mathcal{G}) = \sum_a p(y_A|\mathcal{H}_a)p(\mathcal{H}_a|\mathcal{G})$ ，即对 $\mathcal{G}$ 所编码的任何及全部假设 $\mathcal{H}_a$ 求和。但元假设 $\mathcal{G}$ 与假设 $\mathcal{H}_a$ 的区分有些任意；例如，可以把架构的总体选择——MLP、CNN、transformer——放进 $\mathcal{G}$ ，再让 $\mathcal{H}_a$ 标记不同的 Hyperparameter 设定。再递归一次，对 $\mathcal{G}$ 的贝叶斯模型比较就会在考虑这些架构全部可能超参数设定的同时，对最适合数据的架构作加权评估。

奥卡姆剃刀

为进一步阐释贝叶斯模型比较 (6.30) 背后的机制, 让我们拿起著名的**奥卡姆剃刀** [51], 即稀疏性原理. 它说, 我们应偏好能拟合全部观测的最简单假设. 在机器学习和参数化概率建模中, 该原理常被用作一种启发式: 其他条件相同时, 偏好参数较少的模型. 直观解释是, 参数较多的模型更灵活, 更容易拟合观测数据, 从而更可能过拟合, 也更不可能泛化到新观测.¹⁰⁸

朴素看来, 贝叶斯模型比较 (6.29) 给出了实现这把剃刀的自然方式: 可主观调整先验信念比 $p(\mathcal{H}_1)/p(\mathcal{H}_2)$, 显式偏好较简单假设, 先验地惩罚更复杂模型. 然而, 正如 MacKay [52] 指出的:

自洽的 [贝叶斯] 推断会自动且定量地体现奥卡姆剃刀.

也就是说, 奥卡姆剃刀通过贝叶斯因子客观地内置于贝叶斯模型比较 (6.30).¹⁰⁹

为理解其原因, 注意先验分布 $p(z_{\mathcal{A}}^{(L)} | \mathcal{H}_a)$ 必须归一化. 这意味着, 若给定假设 $\mathcal{H}_a$ 复杂到足以解释极其广泛的潜在观测 $z_{\mathcal{A}}^{(L)}$, 它对任何特定观测 $y_{\mathcal{A}}$ 的支持都必然很小. 因而, 无论实际得到什么观测, 该假设的证据 $p(y_{\mathcal{A}} | \mathcal{H}_a)$ 都会很小. 相反, 如果假设很简单, 先验 $p(z_{\mathcal{A}}^{(L)} | \mathcal{H}_a)$ 会作出受限的一组预测, 却会把支持集中在少数合理结果上, 从而有力地作出这些预测. 因此, 仅凭贝叶斯因子 $p(y_{\mathcal{A}} | \mathcal{H}_1)/p(y_{\mathcal{A}} | \mathcal{H}_2)$, 就会自然偏好仍能正确预测观测 $y_{\mathcal{A}}$ 的最简单模型. 此外, 正确预测的观测越多, 贝叶斯因子越会放大对仍能拟合数据的较简单模型的这种偏好.¹¹⁰

由于贝叶斯因子自动且客观地实现奥卡姆剃刀, 无需再用假设先验 $p(\mathcal{H}_a)$ 主观表达对较简单模型的偏好. 这意味着, 对离散假设集 $\{\mathcal{H}_a\}$, 可选择均匀先验分布, 对每个具体假设 $\mathcal{H}_a$ 给予相同的先验偏好, 而不论其复杂度. 在这一选择下, 贝叶斯模型比较完全由贝叶斯因子刻画:

$$\frac{p(\mathcal{H}_1 | y_{\mathcal{A}})}{p(\mathcal{H}_2 | y_{\mathcal{A}})} = \frac{p(y_{\mathcal{A}} | \mathcal{H}_1)}{p(y_{\mathcal{A}} | \mathcal{H}_2)}. \quad (6.31)$$

因此, 真正应把奥卡姆剃刀视为贝叶斯推断应用于模型比较时的归纳偏置.

归纳偏置

鉴于上一结论, 我们应澄清一个从 §2.1 起就一直非正式提及、现在终于可以正式讨论的概念: **归纳偏置**.

¹⁰⁸ 这里很自然会问: 既然我们已经把全部参数积分掉, 应如何解释过拟合? (在机器学习文献中, 这类系统有时称为非参数模型; 鉴于下面的解释, 我们非常不喜欢这种术语.) 潜在混淆来自“参数”一词的多重用法. 举一个极端例子, 考虑无限宽极限. 尽管形式上从无限多个模型参数出发——至少朴素看来, 这给出了高度过参数化的模型——输出分布的有效理论却完全由核 $K^{(L)}$ 刻画, 而该核可由有限个数据依赖耦合 $\sim N_D^2$ 描述. 因此, 从贝叶斯模型比较的宏观视角看, 控制模型复杂度的是这些耦合, 而不是我们通常所说的参数——可调权重与偏置. 我们将在结语 ϵ 中更深入讨论这一点, 尤其会强调有限宽网络的 $1/n$ 展开如何产生复杂度不断增加的一系列有效理论.

¹⁰⁹ 更多细节和例子参见 MacKay 的出色论述 [52], 其中尤其强调 (深度学习时代之前的) 神经网络.

¹¹⁰ 这类似于贝叶斯模型拟合中, 随着观测累积, 似然因子会压倒先验的方式.

早在 §2.1 中，归纳偏置被介绍为神经网络架构中隐含的内置内容，其作用是让函数集 $\{f(x; \theta)\}$ 更好表示特定数据集 $\mathcal{D}$ 的性质和当前函数逼近任务。从贝叶斯视角看，归纳偏置代表在作出任何观测之前，对期望函数 $f(x)$ 所作的先验假定。更广泛地说，假设和学习算法都可能各自具有一组归纳偏置；例如，我们刚刚指出奥卡姆剃刀是贝叶斯推断的一种归纳偏置。

在 §6.3 与 §6.4 中对无限宽和有限宽 MLP 作具体计算时，我们将遇到多种归纳偏置。这里考虑一个极简单的说明性例子：假定一位贝叶斯主义者以绝对确定的信念认为陈述 B 为假，使其假设 $\mathcal{H}_{\bar{B}}$ 给信念 B 指派零先验概率，即 $p(B|\mathcal{H}_{\bar{B}}) = 0$ 。那么，根据贝叶斯法则 (6.4)，即使该贝叶斯主义者收集了可为 B 提供正证据的新信息 A ， B 的后验也绝不可能更新为零以外的数值。此时， $\mathcal{H}_{\bar{B}}$ 显然是坏假设，其归纳偏置导致一组荒谬固执的信念。反之，如果 B 事实上确为假， $\mathcal{H}_{\bar{B}}$ 就是好假设，因为它可将更多概率分配给其他可能为真的陈述。这个思想推断说明，归纳偏置的利弊取决于真实情况。

回到 §2.1 中不同神经网络架构之归纳偏置的最初例子，一种架构相对于另一种的优势高度依赖数据和任务。原则上，只要知道如何计算这些架构的证据 $p(y_A|\mathcal{H})$ ，就可用贝叶斯模型比较 (6.30)，对不同观测集 y_A 直接比较 MLP、CNN 与 transformer 等架构。¹¹¹ 前几章提出的深度学习有效理论形式体系，恰好为计算不同架构在特定数据集上的这种因子提供了蓝图。我们鼓励读者亲自尝试。

6.3 无限宽下的贝叶斯推断

本节给出无限宽极限下贝叶斯学习的三点结论。首先，计算证据 $p(y_A|\mathcal{H})$ ，并看到对于足够深的网络，贝叶斯模型比较偏好临界性 (§6.3.1)。接着，计算网络输出的后验分布 $p(z_B^{(L)}|y_A, \mathcal{H})$ ，并看到在这一极限下不同输出分量完全独立 (§6.3.2)。最后，计算倒数第二层预激活量的后验分布 $p(z_D^{(L-1)}|y_A, \mathcal{H})$ ，证明它与倒数第二层先验分布 $p(z_D^{(L-1)}|\mathcal{H})$ 相同，从而说明这种无限宽网络缺乏表征学习 (§6.3.3)。

开始之前，先戴上新的贝叶斯眼镜回顾旧知识。在无限宽极限下，网络输出的先验分布是简单的零均值高斯分布

$$p(z_D^{(L)}|\mathcal{H}) = \frac{1}{\sqrt{|2\pi K|^{n_L}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\delta_1, \delta_2 \in \mathcal{D}} K^{\delta_1 \delta_2} z_{i; \delta_1}^{(L)} z_{i; \delta_2}^{(L)}\right), \quad (6.32)$$

其中协方差 $K_{\delta_1 \delta_2} \equiv K_{\delta_1 \delta_2}^{(L)} = K^{(L)}(x_{\delta_1}, x_{\delta_2})$ 由输出层核给出——这里省略层指标——它显式依赖数据集 $\mathcal{D}$ 中的输入对 $x_{\delta_1}, x_{\delta_2}$ ，并隐式依赖 hyperparameters C_b, C_W 。按照我们的广义相对论约定，矩阵 $K^{\delta_1 \delta_2}$ 是协方差矩阵 $K_{\delta_1 \delta_2}$ 的逆

$$\sum_{\delta_2 \in \mathcal{D}} K^{\delta_1 \delta_2} K_{\delta_2 \delta_3} = \delta_{\delta_3}^{\delta_1}, \quad (6.33)$$

¹¹¹ 回顾 §2.1，CNN (2.8) 的设计利用了这样一个事实：计算机视觉数据以空间局域且平移不变的方式组织有用信息。把这一性质纳入架构设计，就是 CNN 的一种归纳偏置；具体假定是，即使一只猫按上上下下左右左右 BA 平移，它仍然是一只 cat。相比 MLP，这种归纳偏置的优势应直接编码在贝叶斯因子 $p(y_A|\mathcal{H}_{\text{CNN}})/p(y_A|\mathcal{H}_{\text{MLP}})$ 中。对任何期望输出为 y_A 、且空间局域性假定是有用归纳偏置的数据集，该比值大概都应大于一。

这里样本指标 δ_1, δ_2 与总 Kronecker delta 的记号碰撞既有趣又令人抱歉；而 $|2\pi K|$ 是 $N_{\mathcal{D}} \times N_{\mathcal{D}}$ 矩阵 $(2\pi K)_{\delta_1 \delta_2}$ 的行列式。

6.3.1 临界性的证据

正如上一节所详述的，证据就是网络输出的先验分布在子样本 $\mathcal{A}$ 的输入 $x_{i;\tilde{\alpha}}$ 所对应的观测真实输出 $y_{i;\tilde{\alpha}}$ 上的取值：

$$p(y_{\mathcal{A}}|\mathcal{H}) = \frac{1}{\sqrt{|2\pi\tilde{K}|^{n_L}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2}\right). \quad (6.34)$$

这里不仅在样本指标 $\tilde{\alpha}$ 上加波浪号，也在核 $\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 上加波浪号，以表示它是由大小为 $N_{\mathcal{A}}$ 的子样本 $\mathcal{A}$ 中输入对 $(x_{\tilde{\alpha}_1}, x_{\tilde{\alpha}_2})$ 构成的 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 子矩阵。重要的是，逆 $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 只相对于集合 $\mathcal{A}$ 中的样本求取，

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{K}_{\tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{\tilde{\alpha}_1 \tilde{\alpha}_3}^{\tilde{\alpha}_1}, \quad (6.35)$$

尤其有 $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \neq K^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 。换言之， $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 不是整个数据集 $\mathcal{D}$ 上核的逆 $K^{\delta_1 \delta_2}$ (6.33) 在 $\delta_1 = \tilde{\alpha}_1, \delta_2 = \tilde{\alpha}_2$ 处的取值；可向后翻阅并比较 (6.53)。相应地，行列式 $|2\pi\tilde{K}|$ 也由这个 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 子矩阵计算。当我们在 §6.3.2 中考察后验时，这套记号的用处和这一区分的关键性将更加清楚。

在详细分析证据 (6.34) 前，应先确定假设空间。对无限宽极限下的 MLP 架构而言，相关超参数只有偏置方差 C_b 、重标度权重方差 C_W 和深度 L 。原则上，每种组合都是不同假设。然而，在大深度渐近极限 $L \gg 1$ 下，根据 §3.2 的讨论和 §5 的分析，核递归通常会指数地趋向零点 $K^* = 0$ 或无穷远 $K^* = \infty$ 处的平凡不动点，或者在临界性处缓慢趋向非平凡不动点。¹¹² 因此，对深网络而言，贝叶斯模型比较实质上归结为比较三个假设 $\mathcal{H}_0, \mathcal{H}_\infty, \mathcal{H}_{\text{critical}}$ ，它们分别对应两个平凡不动点和一个非平凡不动点。

先看只有单个输入 x 时贝叶斯模型比较如何工作。此时核只是标量，证据为

$$p(y|\mathcal{H}) = \frac{1}{(2\pi\tilde{K})^{\frac{n_L}{2}}} \exp\left(-\frac{1}{2\tilde{K}} \sum_{i=1}^{n_L} y_i^2\right). \quad (6.36)$$

输出范数 $\sum_{i=1}^{n_L} y_i^2$ 由给定函数逼近任务固定。¹¹³ 因而，对超参数 $\mathcal{H}$ 的全部依赖都编码在单个数 $\tilde{K}$ 中。

先看 $\mathcal{H}_\infty$ ，此时 $\tilde{K} \rightarrow \infty$ 。式 (6.36) 的指数宗量消失，指数等于一，而前面的归一化因子趋于零。因此证据按幂律消失：

$$p(y|\mathcal{H}_\infty) = \lim_{\tilde{K} \rightarrow \infty} \frac{1}{(2\pi\tilde{K})^{\frac{n_L}{2}}} = 0. \quad (6.37)$$

¹¹²对于某些激活函数，确实存在使核趋向非零平凡不动点 $K^* \neq 0$ 的超参数设定。我们最终也会考察并反对这类假设，不过要等到脚注 115，而且是在先考察双输入证据之后。

¹¹³许多常见分类任务数据集采用独热真实输出：除一个分量 y_i 外全部为零，剩下的单个分量对应正确类别并等于一。对这类数据集， $\sum_{i=1}^{n_L} y_i^2 = 1$ 。

事实上, 输出分布成为所有可能输出范数上的不可归一化均匀分布. 接着考察 $\mathcal{H}_0$, 此时 $\tilde{K} \rightarrow 0$. 归一化因子虽按幂律增长, 指数宗量却趋向负无穷, 因此证据以指数速度趋于零:

$$p(y|\mathcal{H}_0) = \lim_{\tilde{K} \rightarrow 0} \exp \left[-\frac{1}{2\tilde{K}} \sum_{i=1}^{n_L} y_i^2 + O(\log \tilde{K}) \right] = 0. \quad (6.38)$$

回顾 (2.30), 证据 (6.36) 在这一极限下成为 Dirac delta function

$$p(y|\mathcal{H}_0) = \prod_{i=1}^{n_L} \delta(y_i), \quad (6.39)$$

除非所有真实输出都是零向量, 否则这是相当无用的假设. 对一般有限非零输出, 最大证据应位于两个极端之间. 具体而言, 把证据 (6.36) 视为 $\tilde{K}$ 的函数, 它在 $\tilde{K} = \tilde{K}^{(L)}(x, x) \equiv \sum_{i=1}^{n_L} y_i^2 / n_L$ 处达到峰值. 剩余的临界性假设 $\mathcal{H}_{\text{critical}}$ 最接近这一最大值.

对单个输入, 只需让核 $\tilde{K}$ 为一阶量. 对神经网络而言, 这正是为避免单输入的核爆炸与消失问题而施加的条件; 我们用平行易感率条件 $\chi_{\parallel}(K^*) = 1$ 满足它. 爆炸核给出很平、散布于很大输出范数范围的分布, 因而对任何具体范数只提供微弱证据; 消失核在零范数 (6.39) 上提供尖锐支持, 其他地方则毫无支持. 贝叶斯因子 (6.31) 显然偏好在合理输出范数上给出更集中支持的假设. 用奥卡姆剃刀的语言说, $\mathcal{H}_{\infty}$ 过于复杂, 预测每种可能范数; $\mathcal{H}_0$ 过于简单, 只预测一个特定范数. 在深度渐近区给出有限非零 $\tilde{K}$ 的唯一假设是 $\mathcal{H}_{\text{critical}}$, 其初始化超参数满足 $\chi_{\parallel}(K^*) = 1$.¹¹⁴

现在把证据分析推广到两个输入, 其中 $\tilde{\alpha} = \pm$. 直观上, 我们预期得到垂直易感率条件 $\chi_{\perp}(K^*) = 1$, 从而证明对临界假设 $\mathcal{H}_{\text{critical}}$ 的决定性偏好. 为重新得到该条件, 考察两个输入范数相同的情形就足够了:

$$\sum_{i=1}^{n_0} x_{i,+}^2 = \sum_{i=1}^{n_0} x_{i,-}^2. \quad (6.40)$$

回顾把核分解到 $\gamma_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{[a]}$ 基的式 (5.15), 可写

$$\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2} = \begin{pmatrix} \tilde{K}_{[0]} + \tilde{K}_{[2]} & \tilde{K}_{[0]} - \tilde{K}_{[2]} \\ \tilde{K}_{[0]} - \tilde{K}_{[2]} & \tilde{K}_{[0]} + \tilde{K}_{[2]} \end{pmatrix}, \quad (6.41)$$

这里用了同范数 (6.40) 时 $\tilde{K}_{[1]} = 0$ 的事实.

在这一基中, $|2\pi\tilde{K}| = 16\pi^2 \tilde{K}_{[0]} \tilde{K}_{[2]}$, 核的逆为

$$\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} = \frac{1}{4\tilde{K}_{[0]} \tilde{K}_{[2]}} \begin{pmatrix} \tilde{K}_{[0]} + \tilde{K}_{[2]} & -\tilde{K}_{[0]} + \tilde{K}_{[2]} \\ -\tilde{K}_{[0]} + \tilde{K}_{[2]} & \tilde{K}_{[0]} + \tilde{K}_{[2]} \end{pmatrix}, \quad (6.42)$$

¹¹⁴按幂律消失的核在所有实际深度上都给出有限证据. 非常严格地说, 对于这类核——例如 $\tanh$ ——在荒谬深的网络中, 真正的贝叶斯最优 C_W 会比临界值略高一点.

于是式 (6.34) 的指数宗量为

$$\begin{aligned} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2=\pm} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2} &= \sum_{i=1}^{n_L} \frac{1}{4\tilde{K}_{[0]}\tilde{K}_{[2]}} \left[\tilde{K}_{[2]} (y_{i,+} + y_{i,-})^2 + \tilde{K}_{[0]} (y_{i,+} - y_{i,-})^2 \right] \\ &= \frac{\mathbb{Y}_{[0]}}{\tilde{K}_{[0]}} + \frac{\mathbb{Y}_{[2]}}{\tilde{K}_{[2]}}, \end{aligned} \quad (6.43)$$

其中引入了分量

$$\mathbb{Y}_{[0]} \equiv \sum_i^{n_L} \left(\frac{y_{i,+} + y_{i,-}}{2} \right)^2, \quad \mathbb{Y}_{[2]} \equiv \sum_i^{n_L} \left(\frac{y_{i,+} - y_{i,-}}{2} \right)^2. \quad (6.44)$$

合起来得到双输入证据

$$\begin{aligned} p(y_+, y_- | \mathcal{H}) &= \left(16\pi^2 \tilde{K}_{[0]} \tilde{K}_{[2]} \right)^{-\frac{n_L}{2}} \exp \left(-\frac{\mathbb{Y}_{[0]}}{2\tilde{K}_{[0]}} - \frac{\mathbb{Y}_{[2]}}{2\tilde{K}_{[2]}} \right) \\ &= \left[\left(4\pi \tilde{K}_{[0]} \right)^{-\frac{n_L}{2}} \exp \left(-\frac{\mathbb{Y}_{[0]}}{2\tilde{K}_{[0]}} \right) \right] \times \left[\left(4\pi \tilde{K}_{[2]} \right)^{-\frac{n_L}{2}} \exp \left(-\frac{\mathbb{Y}_{[2]}}{2\tilde{K}_{[2]}} \right) \right]. \end{aligned} \quad (6.45)$$

考虑一般的两个输入-输出对 (x_+, y_+) 与 (x_-, y_-) , 其真实输出的平均与差 $\mathbb{Y}_{[0]}, \mathbb{Y}_{[2]}$ (6.44) 均为非零一阶量. 重复单输入证据的论证, 我们偏好尽可能同时满足 $\tilde{K}_{[0]} \approx \mathbb{Y}_{[0]}/n_L = O(1)$ ——来自最大化式 (6.45) 的第一个方括号——和 $\tilde{K}_{[2]} \approx \mathbb{Y}_{[2]}/n_L = O(1)$ ——来自最大化式 (6.45) 的第二个方括号——的假设. 正如 §5 所述, 为使两者都保持一阶, 需要同时设定临界平行易感率条件 $\chi_{\parallel}(K^*) = 1$ 和临界垂直易感率条件 $\chi_{\perp}(K^*) = 1$.¹¹⁵ 因此, 凭借这一临界性的证据, 贝叶斯模型比较表明它完

¹¹⁵最后考察核值非零 $K^* \neq 0$ 的平凡不动点. (例如在 $K^* = 0$ 普适类中, 存在满足 $\chi_{\perp}(K^*) = 1$ 但 $\chi_{\parallel}(K^*) < 1$ 的不动点 K^* .) 为此放松同范数条件 (6.40), 考察最一般的双输入核. 把核投影到 $\gamma_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{[a]}$ 基 (5.15):

$$\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2} = \begin{pmatrix} \tilde{K}_{[0]} + \tilde{K}_{[1]} + \tilde{K}_{[2]} & \tilde{K}_{[0]} - \tilde{K}_{[2]} \\ \tilde{K}_{[0]} - \tilde{K}_{[2]} & \tilde{K}_{[0]} + \tilde{K}_{[1]} + \tilde{K}_{[2]} \end{pmatrix}, \quad (6.46)$$

用 (5.20) 把输出矩阵 $\mathbb{Y}_{\tilde{\alpha}_1 \tilde{\alpha}_2} \equiv \sum_{i=1}^{n_L} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2}$ 分解为

$$\mathbb{Y}_{[0]} = \sum_i \left(\frac{y_{i,+} + y_{i,-}}{2} \right)^2, \quad \mathbb{Y}_{[1]} = \frac{\sum_i y_{i,+}^2 - \sum_i y_{i,-}^2}{2}, \quad \mathbb{Y}_{[2]} = \sum_i \left(\frac{y_{i,+} - y_{i,-}}{2} \right)^2. \quad (6.47)$$

快速计算表明证据为

$$p(y_+, y_- | \mathcal{H}) = \left[4\pi^2 (4\tilde{K}_{[0]}\tilde{K}_{[2]} - \tilde{K}_{[1]}^2) \right]^{-\frac{n_L}{2}} \exp \left[-\frac{(4\tilde{K}_{[0]}\mathbb{Y}_{[2]} + 4\tilde{K}_{[2]}\mathbb{Y}_{[0]} - 2\tilde{K}_{[1]}\mathbb{Y}_{[1]})}{2(4\tilde{K}_{[0]}\tilde{K}_{[2]} - \tilde{K}_{[1]}^2)} \right]. \quad (6.48)$$

相比 $\tilde{K}_{[1]}\mathbb{Y}_{[1]} \leq 0$ 的假设, 满足 $\tilde{K}_{[1]}\mathbb{Y}_{[1]} > 0$ 的假设证据更大. 特别地, 若不动点平凡, 则即便核的不动点值非零 $K^* \neq 0$, 平行扰动 $\tilde{K}_{[1]}$ 也总是指数消失. 因而这类假设相较 $\mathcal{H}_{\text{critical}}$ 会受到抑制, 论证至此完成.

要使这一区别重要, 必须有非零 $\mathbb{Y}_{[1]}$, 即 $\sum_i y_{i,+}^2 \neq \sum_i y_{i,-}^2$. 对用作一般函数逼近器的网络, 或网络输出为一般量并在下游用于其他任务的情形, 这可能很重要; 对所有真实输出范数相同的深度学习任务, 这可能并不重要.

全偏好 $\mathcal{H}_{\text{critical}}$.¹¹⁶

编程说明：既然以 $\mathcal{H}$ 为条件已经深深刻在脑中，为简化记号，从这里起将再次省略这一条件依赖。

6.3.2 不要连接在一起

现在来计算无限宽时的完整后验分布 (6.25).¹¹⁷ 分母中的证据 $p(y_{\mathcal{A}})$ 已由式 (6.34) 给出，因此只需考察分子中的联合分布 $p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)})$. 为讨论后验，我们把数据分成两个子样本 $\mathcal{D} \equiv \mathcal{A} \cup \mathcal{B}$ ：在 $\mathcal{A}$ 上已经观测到真实输出 $y_{\mathcal{A}}$ ，而在 $\mathcal{B}$ 上要推断输出值. 按照这一划分，联合分布为

$$\begin{aligned} p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)}) &= \frac{1}{\sqrt{|2\pi K|^{n_L}}} \exp \left[-\frac{1}{2} \sum_i \left(\sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} K^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2} + \sum_{\tilde{\alpha}_1 \in \mathcal{A}, \tilde{\beta}_2 \in \mathcal{B}} K^{\tilde{\alpha}_1 \tilde{\beta}_2} y_{i;\tilde{\alpha}_1} z_{i;\tilde{\beta}_2}^{(L)} \right. \right. \\ &\quad \left. \left. + \sum_{\tilde{\beta}_1 \in \mathcal{B}, \tilde{\alpha}_2 \in \mathcal{A}} K^{\tilde{\beta}_1 \tilde{\alpha}_2} z_{i;\tilde{\beta}_1}^{(L)} y_{i;\tilde{\alpha}_2} + \sum_{\tilde{\beta}_1, \tilde{\beta}_2 \in \mathcal{B}} K^{\tilde{\beta}_1 \tilde{\beta}_2} z_{i;\tilde{\beta}_1}^{(L)} z_{i;\tilde{\beta}_2}^{(L)} \right) \right]. \end{aligned} \quad (6.49)$$

其中 $K^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 、 $K^{\tilde{\alpha}_1 \tilde{\beta}_2}$ 、 $K^{\tilde{\beta}_1 \tilde{\alpha}_2}$ 和 $K^{\tilde{\beta}_1 \tilde{\beta}_2}$ 是逆核矩阵

$$K^{\delta_1 \delta_2} = \begin{pmatrix} K^{\tilde{\alpha}_1 \tilde{\alpha}_2} & K^{\tilde{\alpha}_1 \tilde{\beta}_2} \\ K^{\tilde{\beta}_1 \tilde{\alpha}_2} & K^{\tilde{\beta}_1 \tilde{\beta}_2} \end{pmatrix}, \quad (6.50)$$

$$K_{\delta_1 \delta_2} = \begin{pmatrix} \tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2} & K_{\tilde{\alpha}_1 \tilde{\beta}_2} \\ K_{\tilde{\beta}_1 \tilde{\alpha}_2} & K_{\tilde{\beta}_1 \tilde{\beta}_2} \end{pmatrix}. \quad (6.51)$$

的各个分块；它是整个 $N_{\mathcal{D}} \times N_{\mathcal{D}}$ 核矩阵的逆. 为继续计算，需要把逆矩阵 (6.50) 的各个分块同核分解 (6.51) 的各分块联系起来，因为回顾

$$K_{\delta_1 \delta_2} = \frac{1}{n_L} \sum_i \mathbb{E} \left[z_i^{(L)}(x_{\delta_1}) z_i^{(L)}(x_{\delta_2}) \right] + O\left(\frac{1}{n}\right). \quad (6.52)$$

真正由数据自然定义的正是这些核分块.¹¹⁸ 按照逆矩阵公式 (6.33) 显式求逆后，式 (6.50) 的各分块可以用式 (6.51) 的核分块和 $\mathcal{A}$ 上的逆子矩阵 $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 表示为

¹¹⁶ 严格地说，这里证明的是贝叶斯先验分布中对临界性的偏好. 在 §9.4 中，我们还会在初始化分布中发现对临界性的自然偏好：这种调节对于控制基于梯度的学习中出现的梯度爆炸与消失问题是必要的。

¹¹⁷ Williams 在 [53] 中最早为单隐藏层网络求得了这一分布。

¹¹⁸ $\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 上方的波浪号表示它只是核在集合 $\mathcal{A}$ 的样本上求值得的子矩阵；其逆已在式 (6.35) 中明确定义，并记作 $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$. 完整核的对称性 $K_{\delta_1 \delta_2} = K_{\delta_2 \delta_1}$ 还给出 $\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2} = \tilde{K}_{\tilde{\alpha}_2 \tilde{\alpha}_1}$ 、 $K_{\tilde{\beta}_1 \tilde{\beta}_2} = K_{\tilde{\beta}_2 \tilde{\beta}_1}$ 和 $K_{\tilde{\beta} \tilde{\alpha}} = K_{\tilde{\alpha} \tilde{\beta}}$.

$$K^{\tilde{\alpha}_1 \tilde{\alpha}_2} = \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} + \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \sum_{\dot{\beta}_3, \dot{\beta}_4 \in \mathcal{B}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_3} K_{\tilde{\alpha}_3 \dot{\beta}_3} \mathbb{K}^{\dot{\beta}_3 \dot{\beta}_4} K_{\dot{\beta}_4 \tilde{\alpha}_4} \tilde{K}^{\tilde{\alpha}_4 \tilde{\alpha}_2}, \quad (6.53)$$

$$K^{\tilde{\alpha}_1 \dot{\beta}_2} = - \sum_{\tilde{\alpha}_3 \in \mathcal{A}, \dot{\beta}_3 \in \mathcal{B}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_3} K_{\tilde{\alpha}_3 \dot{\beta}_3} \mathbb{K}^{\dot{\beta}_3 \dot{\beta}_2}, \quad (6.54)$$

$$K^{\dot{\beta}_1 \tilde{\alpha}_2} = - \sum_{\tilde{\alpha}_3 \in \mathcal{A}, \dot{\beta}_3 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_3} K_{\dot{\beta}_3 \tilde{\alpha}_3} \tilde{K}^{\tilde{\alpha}_3 \tilde{\alpha}_2}, \quad (6.55)$$

$$K^{\dot{\beta}_1 \dot{\beta}_2} = \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2}, \quad (6.56)$$

其中我们不得不事后引入并命名后验协方差

$$\mathbb{K}_{\dot{\beta}_1 \dot{\beta}_2} = K_{\dot{\beta}_1 \dot{\beta}_2} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} K_{\dot{\beta}_1 \tilde{\alpha}_3} \tilde{K}^{\tilde{\alpha}_3 \tilde{\alpha}_4} K_{\tilde{\alpha}_4 \dot{\beta}_2}, \quad (6.57)$$

式 (6.56) 则通过对式 (6.57) 求逆而隐式定义, 即

$$\sum_{\dot{\beta}_3 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} \mathbb{K}_{\dot{\beta}_2 \dot{\beta}_3} = \delta_{\dot{\beta}_3}^{\dot{\beta}_1}. \quad (6.58)$$

这些关系至关重要, 下面逐一检验逆公式 (6.33) 的所有分块. 首先考察 $\delta_{\dot{\beta}_3}^{\delta_1} \rightarrow \delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1}$ 分量:

$$\begin{aligned} \sum_{\delta_2 \in \mathcal{D}} K^{\tilde{\alpha}_1 \delta_2} K_{\delta_2 \tilde{\alpha}_3} &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}} K^{\tilde{\alpha}_1 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \tilde{\alpha}_3} + \sum_{\dot{\beta}_2 \in \mathcal{B}} K^{\tilde{\alpha}_1 \dot{\beta}_2} K_{\dot{\beta}_2 \tilde{\alpha}_3} \\ &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{K}_{\tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1}. \end{aligned} \quad (6.59)$$

第一行按 $\mathcal{D} = \mathcal{A} \cup \mathcal{B}$ 把对 δ_2 的求和拆成对 $\tilde{\alpha}_2 \in \mathcal{A}$ 与 $\dot{\beta}_2 \in \mathcal{B}$ 的求和; 第二行代入逆分块 (6.53)、(6.54), 最后利用 $\tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 是子矩阵 $\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的逆 (6.35). 其次考察 $\delta_{\dot{\beta}_3}^{\delta_1} \rightarrow \delta_{\dot{\beta}_3}^{\dot{\beta}_1}$ 分量:

$$\begin{aligned} \sum_{\delta_2 \in \mathcal{D}} K^{\dot{\beta}_1 \delta_2} K_{\delta_2 \dot{\beta}_3} &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}} K^{\dot{\beta}_1 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \dot{\beta}_3} + \sum_{\dot{\beta}_2 \in \mathcal{B}} K^{\dot{\beta}_1 \dot{\beta}_2} K_{\dot{\beta}_2 \dot{\beta}_3} \\ &= \sum_{\dot{\beta}_2 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} \left(K_{\dot{\beta}_2 \dot{\beta}_3} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_2 \in \mathcal{A}} K_{\dot{\beta}_2 \tilde{\alpha}_3} \tilde{K}^{\tilde{\alpha}_3 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \dot{\beta}_3} \right) = \sum_{\dot{\beta}_2 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} \mathbb{K}_{\dot{\beta}_2 \dot{\beta}_3} = \delta_{\dot{\beta}_3}^{\dot{\beta}_1}. \end{aligned} \quad (6.60)$$

同样, 第一行按数据划分拆分求和, 第二行代入逆分块 (6.55)、(6.56). 括号内正是后验协方差 $\mathbb{K}_{\dot{\beta}_1 \dot{\beta}_2}$ 的定义 (6.57), 再用其逆关系 (6.58) 即得结论. 最后考察非对角分块:

$$\begin{aligned} \sum_{\delta_2 \in \mathcal{D}} K^{\tilde{\alpha}_1 \delta_2} K_{\delta_2 \dot{\beta}_3} &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}} K^{\tilde{\alpha}_1 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \dot{\beta}_3} + \sum_{\dot{\beta}_2 \in \mathcal{B}} K^{\tilde{\alpha}_1 \dot{\beta}_2} K_{\dot{\beta}_2 \dot{\beta}_3} \\ &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}, \dot{\beta}_2 \in \mathcal{B}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \dot{\beta}_2} \left(\delta_{\dot{\beta}_3}^{\dot{\beta}_2} + \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \sum_{\dot{\beta}_4 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_2 \dot{\beta}_4} K_{\dot{\beta}_4 \tilde{\alpha}_4} \tilde{K}^{\tilde{\alpha}_4 \tilde{\alpha}_3} K_{\tilde{\alpha}_3 \dot{\beta}_3} - \sum_{\dot{\beta}_4 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_2 \dot{\beta}_4} K_{\dot{\beta}_4 \dot{\beta}_3} \right) \\ &= \sum_{\tilde{\alpha}_2 \in \mathcal{A}, \dot{\beta}_2 \in \mathcal{B}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} K_{\tilde{\alpha}_2 \dot{\beta}_2} \left(\delta_{\dot{\beta}_3}^{\dot{\beta}_2} - \sum_{\dot{\beta}_4 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_2 \dot{\beta}_4} \mathbb{K}_{\dot{\beta}_4 \dot{\beta}_3} \right) = 0. \end{aligned} \quad (6.61)$$

这里仍依次使用：(i) 按 $\mathcal{D} = \mathcal{A} \cup \mathcal{B}$ 拆分求和；(ii) 代入逆分块 (6.53) 与 (6.54)；(iii) 使用后验协方差 (6.57) 及其逆式 (6.58). 所有分块都通过了检验.

现在我们对求逆已有把握，把子矩阵表达式 (6.53)–(6.56) 代回联合先验 (6.49). 因为后验 (6.25) 只依赖输出 $z_B^{(L)}$ ，可以略去与 $z_B^{(L)}$ 无关的 y_A 项及归一化因子，只保留

$$p(y_A, z_B^{(L)}) \propto \exp \left[-\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\dot{\beta}_1, \dot{\beta}_2 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} z_{i; \dot{\beta}_1}^{(L)} z_{i; \dot{\beta}_2}^{(L)} \right. \\ \left. + \sum_{i=1}^{n_L} \sum_{\dot{\beta}_1 \in \mathcal{B}, \tilde{\alpha}_1 \in \mathcal{A}} z_{i; \dot{\beta}_1}^{(L)} \left(\sum_{\tilde{\alpha}_2 \in \mathcal{A}, \dot{\beta}_2 \in \mathcal{B}} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} K_{\dot{\beta}_2 \tilde{\alpha}_2} \tilde{K}^{\tilde{\alpha}_2 \tilde{\alpha}_1} \right) y_{i; \tilde{\alpha}_1} \right]. \quad (6.62)$$

接下来应当已经驾轻就熟：完成平方，并略去指数中新出现的、与 $z_B^{(L)}$ 无关的加性常数，得到

$$p(y_A, z_B^{(L)}) \propto \exp \left[-\frac{1}{2} \sum_{i, \dot{\beta}_1, \dot{\beta}_2} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} \left(z_{i; \dot{\beta}_1}^{(L)} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4} K_{\dot{\beta}_1 \tilde{\alpha}_3} \tilde{K}^{\tilde{\alpha}_3 \tilde{\alpha}_4} y_{i; \tilde{\alpha}_4} \right) \right. \\ \left. \times \left(z_{i; \dot{\beta}_2}^{(L)} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6} K_{\dot{\beta}_2 \tilde{\alpha}_5} \tilde{K}^{\tilde{\alpha}_5 \tilde{\alpha}_6} y_{i; \tilde{\alpha}_6} \right) \right]. \quad (6.63)$$

式 (6.63) 仍是高斯分布，其方差为后验协方差 $\mathbb{K}_{\dot{\beta}_1 \dot{\beta}_2}$ ，并具有非零后验均值

$$m_{i; \dot{\beta}}^\infty = \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} K_{\dot{\beta} \tilde{\alpha}_1} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2}. \quad (6.64)$$

上标 ∞ 提醒我们这里取的是无限宽极限. 最后，后验分布 (6.25) 正比于联合先验 (6.63)：

$$p(z_B^{(L)} | y_A) \propto p(y_A, z_B^{(L)}). \quad (6.65)$$

作为 $z_B^{(L)}$ 的函数，后验还由式 (6.5) 自动归一化. 因而给式 (6.63) 写出高斯归一化因子，便得到无限宽后验：

$$p(z_B^{(L)} | y_A) = \frac{1}{\sqrt{|2\pi \mathbb{K}|^{n_L}}} \exp \left[-\frac{1}{2} \sum_{i, \dot{\beta}_1, \dot{\beta}_2} \mathbb{K}^{\dot{\beta}_1 \dot{\beta}_2} (z_{i; \dot{\beta}_1}^{(L)} - m_{i; \dot{\beta}_1}^\infty) (z_{i; \dot{\beta}_2}^{(L)} - m_{i; \dot{\beta}_2}^\infty) \right]. \quad (6.66)$$

后验均值 $m_{i; \dot{\beta}}^\infty$ 表示：纳入 $\mathcal{A}$ 中所有输入的真实输出 y_A 后，我们对 $\mathcal{B}$ 中输入 $x_{j; \dot{\beta}}$ 的期望网络输出所作的更新判断；因此正如式 (6.64) 所示，它显式依赖于样本 $\mathcal{A}$ 中的真实输入–输出对 x_A 与 y_A . 先验预测均值为零，体现了平均输出趋于零的归纳偏置；后验预测现已移到非零值. 非零后验均值正是学习终于发生的标志. 此外，后验协方差 $\mathbb{K}_{\dot{\beta}_1 \dot{\beta}_2}$ 编码置信区间：协方差越小，后验在均值附近越尖锐，模型对预测越有信心.

从实践看，按照式 (6.64) 计算均值预测 $m_{i; \dot{\beta}_1}^\infty$ ，原则上需要求逆并存储 $N_A \times N_A$ 子矩阵 $\tilde{K}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$. 随观测数 N_A 增加，求逆成本迅速增长.¹¹⁹ 这个隐蔽问题解释了为何

¹¹⁹例如 Gauss–Jordan 消元的计算成本按 $\sim N_A^3$ 标度，并要求在内存中保存 $N_A \times N_A$ 维逆矩阵. 注意到后验均值实际只需逆矩阵与观测的矩阵–向量积 $\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{K}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2}$ ，虽能稍作改进，却仍不足以让大数据集上的贝叶斯学习在实践中同基于梯度的学习竞争.

朴素的贝叶斯学习虽在理论上优雅，却不适用于大数据集；模型拟合基本上必须依赖 MLE (6.20) 等近似方法。下一章（第 7 节）还会讨论这一点。

无论从理论还是实践看，无限宽后验均值还有另一个严重问题。由式 (6.64) 可见，输出分量 i 上的均值预测完全独立于其他 $j \neq i$ 分量上的观测 $y_{j;\mathcal{A}}$ ；不同输出分量的更新最优估计因而完全不相关，尽管不同分量 j 的观测原则上可能为分量 i 提供非常有用的信息。¹²⁰ 事实上，由式 (6.66) 可见，后验分解为

$$p(z_{i;\mathcal{B}}^{(L)}, z_{j;\mathcal{B}}^{(L)} | y_{i;\mathcal{A}}, y_{j;\mathcal{A}}) = p(z_{i;\mathcal{B}}^{(L)} | y_{i;\mathcal{A}}) p(z_{j;\mathcal{B}}^{(L)} | y_{j;\mathcal{A}}), \quad i \neq j. \quad (6.67)$$

这意味着不同输出分量完全统计独立。¹²¹ 这种独立性可以追溯到无限宽先验分布的类似性质

$$p(z_{i;\mathcal{A}}^{(L)}, z_{j;\mathcal{A}}^{(L)}) = p(z_{i;\mathcal{A}}^{(L)}) p(z_{j;\mathcal{A}}^{(L)}), \quad i \neq j. \quad (6.68)$$

我们早已见过这一性质，例如式 (5.106)。因此，在贝叶斯学习下，输出特征不会连接在一起。回顾前面对归纳偏置的讨论（第 6.2.2 节），这个先验把一套荒谬而顽固的信念赋予后验：它以绝对确定性认定输出分量完全独立。无论观测集 $\mathcal{A}$ 有多大，任何数量的学习都无法治愈这种归纳偏置；在无限宽极限中，数据永远压不过该先验偏置。

幸运的是，对贝叶斯学习和基于梯度的学习这两类学习算法而言，只要离开无限宽极限、研究实践中真正使用的有限宽网络，这个问题就能彻底治愈……

6.3.3 表征学习的缺失

鉴于后验中不同输出分量彼此独立，一个自然的后续问题是：无限宽下的贝叶斯学习是否能够实现表征学习。这里将明确证明，答案是不能。

作为这一问题的一个代表性化身，给定观测 $y_{\mathcal{A}}$ ，我们计算完整样本集 $\mathcal{D}$ 上倒数第二层 $\ell = L - 1$ 的预激活量后验分布：

$$p(z_{\mathcal{D}}^{(L-1)} | y_{\mathcal{A}}) = \frac{p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)}) p(z_{\mathcal{D}}^{(L-1)})}{p(y_{\mathcal{A}})}. \quad (6.69)$$

这是贝叶斯法则 (6.4) 的一个应用；它来自把乘法法则 (6.1) 用于观测 $y_{\mathcal{A}}$ 与倒数第二层预激活量 $z_{\mathcal{D}}^{(L-1)}$ 的联合分布 $p(y_{\mathcal{A}}, z_{\mathcal{D}}^{(L-1)})$ 。这里，似然 $p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)})$ 是层间条件分布 $p(z_{\mathcal{A}}^{(L)} | z_{\mathcal{D}}^{(L-1)})$ 在观测集 $z_{\mathcal{A}}^{(L)} \rightarrow y_{\mathcal{A}}$ 上的取值。

这个条件分布的形式已经熟知：它就是推导预激活量逐层表征群流时所需的对象 (4.69)。一般而言，该分布涉及随机度量 $\hat{G}_{\hat{\alpha}_1 \hat{\alpha}_2}^{(L)} = \hat{G}_{\hat{\alpha}_1 \hat{\alpha}_2}^{(L)}(z_{\mathcal{D}}^{(L-1)})$ 。然而，在无限宽极限下，度量变得完全确定： $\hat{G}_{\hat{\alpha}_1 \hat{\alpha}_2}^{(L)} \rightarrow G_{\hat{\alpha}_1 \hat{\alpha}_2}^{(L)}$ ，不再以任何方式依赖倒数第二层预激活量 $z_{\mathcal{D}}^{(L-1)}$ 。因而，无限宽下把确定性度量换成核后，似然为

$$p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)}) = \frac{1}{\sqrt{|2\pi \tilde{K}^{(L)}|^{n_L}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \tilde{K}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2}\right) = p(y_{\mathcal{A}}), \quad (6.70)$$

¹²⁰ 知识蒸馏 [54] 正是以输出分量之间的这种相关为基础。例如网络对手写数字图像作分类时，某个“2”可能更像“7”，也可能更像“3”；尤其当网络输出还要用于下游任务时，这类特征信息十分有用。

¹²¹ 公平地说，问题出在无限宽极限本身：用梯度学习训练的无限宽网络，其不同输出分量也会去相关（第 10 节）。

于是倒数第二层后验 (6.69) 退化为先验：

$$p\left(z_{\mathcal{D}}^{(L-1)} \middle| y_{\mathcal{A}}\right) = p\left(z_{\mathcal{D}}^{(L-1)}\right). \quad (6.71)$$

既然后验等于先验，对 $y_{\mathcal{A}}$ 的观测便没有给倒数第二层表征带来任何改变；所以，无限宽下不存在表征学习。

这种表征学习的缺失源于无限宽联合分布 $p\left(z_{\mathcal{D}}^{(\ell)}, z_{\mathcal{D}}^{(\ell+1)}\right)$ 中缺乏层间相关，因而对所有 $\ell < L$ 的隐藏层都成立。这是无限宽假设的又一种糟糕归纳偏置：不论观测到怎样的 $y_{\mathcal{A}}$ ，任何数量的新信息都无法让网络更新隐藏层 $\ell < L$ 中的表征。

这种状况颇为悲哀，因为设置许多层的全部意义——事实上也是深度学习整体上的主要动机——正是在这些隐藏层中学习复杂表征。接下来将看到，只要离开无限宽极限并考察有限宽效应，就能同时解决表征学习缺失和输出无法连接在一起的问题。¹²²

6.4 有限宽下的贝叶斯推断

本节将给出有限宽贝叶斯学习的三点结论。首先，我们会说明，由于神经元之间存在非高斯相互作用，有限宽神经网络会自动获得偏好神经关联的归纳偏置，从而自然倾向于 Hebb 学习（第 6.4.1 节）。在此基础上，我们将依次展示这类学习如何发生：先计算网络输出后验分布 $p\left(z_{\mathcal{B}}^{(L)} \middle| y_{\mathcal{A}}\right)$ 的均值，说明先验中的层内神经相互作用如何在输出分量之间产生非平凡相关（第 6.4.2 节）；再计算倒数第二层预激活量的后验分布 $p\left(z_{\mathcal{B}}^{(L-1)} \middle| y_{\mathcal{A}}\right)$ ，说明层间相互作用如何使先验与后验之间产生非零平移，从而标志有限宽下存在表征学习（第 6.4.3 节）。

6.4.1 Hebb 学习有限公司

本小节将看到，有限宽神经网络具有一种促进神经关联的归纳偏置。为解释 **Hebb 学习**，先请荣誉嘉宾 Donald Hebb 讲几句话：

总体思想由来已久：任何两个细胞或细胞系统若反复同时活动，就会倾向于变得“关联”，使其中一个的活动促进另一个的活动。

Donald Hebb, 1949 年经典著作行为的组织 [55].

(掌声.)

非常感谢。

传说中的 Donald Hebb.

Hebb 原本考虑的是生物神经元，但 Hebb 学习也已成为人工神经元系统的一项常

¹²²在第 10 节中，我们还会证明，理论上以梯度学习训练的无限宽网络系统同样缺少表征学习。第 11 节则通过转向有限宽，在实践中解决这一问题。

用指导原则. 事实上, 每当讨论有限宽先验分布中存在神经相互作用时, 我们都已经见过这种偏好神经关联的归纳偏置. 为把它明确展示出来, 下面显式确定初始化时有效预激活量分布中一个预激活量对另一个的神经影响.

具体而言, 设单个输入 x 被送入网络, 并且我们已经检查到第 ℓ 层第一个预激活量的值 $z_1^{(\ell)} = \tilde{z}_1^{(\ell)}$ 大于典型值. 给定这个反常值 $\tilde{z}_1^{(\ell)}$, 可以询问第二个预激活量 $z_2^{(\ell)}$ 是否也可能反常地大. 这种神经关联或影响编码在条件分布

$$p(z_2^{(\ell)} | \tilde{z}_1^{(\ell)}) = \frac{p(\tilde{z}_1^{(\ell)}, z_2^{(\ell)})}{p(\tilde{z}_1^{(\ell)})}. \quad (6.72)$$

中. 注意, 在无限宽下, 神经元先验由式 (5.106) 分解, 因而 $p(z_2^{(\ell)} | \tilde{z}_1^{(\ell)}) = p(z_2^{(\ell)})$; 由此立即看出, 这一极限中完全不存在神经关联.

为计算有限宽网络中的这种关联, 回顾第 4.4 节中 m 个神经元分布的作用量表示 (4.97):

$$p(z_1, \dots, z_m) \propto \exp\left(-\frac{g_m}{2} \sum_{i=1}^m z_i^2 + \frac{v}{8} \sum_{i,j=1}^m z_i^2 z_j^2\right). \quad (6.73)$$

这里暂时省略变量和耦合的层指标. 二次耦合 g_m 由式 (4.102) 隐式给出:

$$\frac{1}{g_m} = G^{(\ell)} - \frac{m+2}{2n_{\ell-1}} \frac{V^{(\ell)}}{G^{(\ell)}} + O\left(\frac{1}{n^2}\right), \quad (6.74)$$

其中突出写出了耦合对 m 的依赖. 类似地, 四次耦合 由式 (4.103) 给出:

$$v = \frac{1}{n_{\ell-1}} \frac{V^{(\ell)}}{(G^{(\ell)})^4} + O\left(\frac{1}{n^2}\right). \quad (6.75)$$

在这一 $1/n$ 阶上, 它与 m 无关. 分别在 $m=1$ 和 $m=2$ 个神经元上计算作用量表示 (6.73), 再把所得分布代入条件分布 (6.72), 得到

$$p(z_2 | \tilde{z}_1) \propto \exp\left[-\frac{g_2}{2} z_2^2 + \frac{v}{8} (z_2^4 + 2z_2^2 \tilde{z}_1^2)\right]. \quad (6.76)$$

与上一节类似, 对这种条件分布只需保留作用量中依赖 z_2 的项.

有了条件分布后, 来计算若干条件期望. 这一分布显然是 z_2 的偶函数, 即在符号翻转 $z_2 \leftrightarrow -z_2$ 下不变, 因此包括条件均值在内的所有奇数点相关函数都为零. 第一个非平凡可观测量因而是两点相关函数, 也就是条件方差:

$$\begin{aligned} \int dz_2 p(z_2 | \tilde{z}_1) z_2^2 &= \frac{\int dz_2 \exp\left[-\frac{g_2}{2} z_2^2 + \frac{v}{8} (z_2^4 + 2z_2^2 \tilde{z}_1^2)\right] z_2^2}{\int dz_2 \exp\left[-\frac{g_2}{2} z_2^2 + \frac{v}{8} (z_2^4 + 2z_2^2 \tilde{z}_1^2)\right]} \\ &= \frac{\int dz_2 e^{-g_2 z_2^2/2} \left[z_2^2 + \frac{v}{8} (z_2^6 + 2z_2^4 \tilde{z}_1^2) + O(v^2)\right]}{\int dz_2 e^{-g_2 z_2^2/2} \left[1 + \frac{v}{8} (z_2^4 + 2z_2^2 \tilde{z}_1^2) + O(v^2)\right]} \\ &= \frac{g_2^{-1} + \frac{v}{8} (15g_2^{-3} + 6g_2^{-2} \tilde{z}_1^2)}{1 + \frac{v}{8} (3g_2^{-2} + 2g_2^{-1} \tilde{z}_1^2)} + O(v^2) \\ &= g_2^{-1} + \frac{v}{2} g_2^{-2} (3g_2^{-1} + \tilde{z}_1^2) + O(v^2). \end{aligned} \quad (6.77)$$

第一行在分子中使用式 (6.76), 同时在分母中计算其归一化; 第二行把分子、分母都按 v 展开; 第三行计算单变量高斯积分; 最后一行再把分母按 v 展开. 代入二次耦合 (6.74) 和四次耦合 (6.75), 并恢复层指标, 得到

$$\int dz_2^{(\ell)} p(z_2^{(\ell)} | \tilde{z}_1^{(\ell)}) (z_2^{(\ell)})^2 = G^{(\ell)} + \frac{1}{2} \left[(\tilde{z}_1^{(\ell)})^2 - G^{(\ell)} \right] \left[\frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^2} \right] + O\left(\frac{1}{n^2}\right). \quad (6.78)$$

顺便为后文指出: 把神经元指标 1, 2 替换为任意 i_1, i_2 (其中 $i_1 \neq i_2$), 这一结果对任意不同神经元对都成立.

条件方差 (6.78) 蕴含相当有趣的物理.

第一个预激活量平方的期望为 $\mathbb{E} \left[(\tilde{z}_1^{(\ell)})^2 \right] = G^{(\ell)}$. 若观测值 $(\tilde{z}_1^{(\ell)})^2$ 大于或小于这个期望, 那么 $z_2^{(\ell)}$ 的方差本身也会大于或小于典型值. 因此, $z_1^{(\ell)}$ 与 $z_2^{(\ell)}$ 的反常放电彼此相关.¹²³ 该效应正比于式 (6.78) 第二个方括号中的归一化四点顶点; 由式 (5.128) 和 (5.129) 可知, 在临界性处, 它在各普适类中都正比于 ℓ/n . 换言之, 更深层具有建立更多神经关联的归纳偏置. 而且, 这些关联只由有限宽时诱导的有效作用量相互作用所介导. 很快将看到, 非平凡表征学习正是这些关联的直接后代.

注意, 这一结果应解释为反常性的倾向, 而不是保证. 条件方差 (6.78) 适用于任意神经元对; 所以, 条件于某个特定神经元 i_* 的范数大于或小于期望值, 所有其他 $i \neq i_*$ 的神经元都更可能具有较大或较小范数, 但并非全部都会如此. 在实际网络的一次具体实现中, 恰好具有较大或较小范数的那些神经元, 才更可能随着学习推进而同 i_* 建立相关.

Hebb 学习常概括为一句口号: 一起放电的神经元连接在一起. 这里看到, 条件于 $\tilde{z}_1$ 的一次反常放电, 另一个预激活量 (例如 z_2) 本身发生反常放电的可能性会大得多. 有限宽网络这种一起放电的倾向, 既是贝叶斯学习前先验信念的归纳偏置, 也是基于梯度学习前初始化分布的归纳偏置. 为理解连接在一起这一部分, 下面考察贝叶斯后验.¹²⁴

¹²³读者或许还记得脚注 9 (第 1.2 节): 非平凡连通四点相关函数 衡量出现离群值的可能性. 在统计学中, 对单变量分布, 这称为超额峰度; 这里得到的是多神经元推广 (显然可以称为共峰度). 特别地, 观测到离群值 $z_1^{(\ell)} = \tilde{z}_1^{(\ell)}$ 意味着我们也更可能看到 $z_2^{(\ell)}$ 取离群值. 附录 A 末尾将给出这一现象的信息论重述, 并进一步说明网络应有多深, 才能最好地利用它.

¹²⁴在某些人工神经元模型——例如 Hopfield 网络——中, Hebb 学习往往是手工加入的. 例如, 有一种显式实现 Hebb 原理的学习规则: 对给定输入 x 观测到活动 $z_i(x)$ 和 $z_j(x)$ 后, 按 $W_{ij} \propto z_i(x)z_j(x)$ 更新连接神经元 i 与 j 的权重. 相比之下, 任何有限宽前馈网络都应当自然地自动包含 Hebb 学习. 为进一步强调这一点, 我们会在第 ∞ 节对梯度下降更新作类似计算. 由于先验与初始化分布具有相同形式, 我们预期所有经过学习的有限宽网络都会自动包含 Hebb 学习原理, 无论采用贝叶斯学习还是基于梯度的学习.

6.4.2 连接在一起

再戴上如今已经适应的贝叶斯透镜，回顾一下. 由式 (4.80) 可知，在大而有限的宽度下，预激活量的先验分布是近高斯的：

$$p(z_{\mathcal{D}}^{(L)}) \propto \exp \left[-\frac{1}{2} \sum_{j, \delta_1, \delta_2} g^{\delta_1 \delta_2} z_{j; \delta_1}^{(L)} z_{j; \delta_2}^{(L)} + \frac{1}{8} \sum_{j, k, \delta_1, \dots, \delta_4} v^{(\delta_1 \delta_2)(\delta_3 \delta_4)} z_{j; \delta_1}^{(L)} z_{j; \delta_2}^{(L)} z_{k; \delta_3}^{(L)} z_{k; \delta_4}^{(L)} + \dots \right]. \quad (6.79)$$

提醒一下，二次耦合 $g^{\delta_1 \delta_2} \equiv g_{(L)}^{\delta_1 \delta_2}$ (式 (4.81)) 和四次耦合 $v^{(\delta_1 \delta_2)(\delta_3 \delta_4)} \equiv v_{(L)}^{(\delta_1 \delta_2)(\delta_3 \delta_4)}$ (式 (4.82)) 显式依赖数据集 $\mathcal{D}$ 中成组的输入，并隐式依赖 $\mathcal{H}$ 超参数 C_b 、 C_W 、各层宽度 n_ℓ 和深度 L . 由于先验中不同输出预激活量之间存在非零的层内相互作用，后验中的网络输出分量之间将出现非零相关.

与无限宽情形相同，从先验 (6.79) 出发，将观测值代入为 $z_{i; \tilde{\alpha}}^{(L)} \rightarrow y_{i; \tilde{\alpha}}$ ，同时保留对 $z_{i; \tilde{\beta}}^{(L)}$ 的依赖，便得到 $p(z_{\mathcal{B}}^{(L)} | y_{\mathcal{A}}) \propto p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)})$. 对作用量的二次项，完全重复无限宽极限中的操作 (第 6.3.2 节)，只是把逆核替换为有限宽二次耦合 $K^{\delta_1 \delta_2} \rightarrow g^{\delta_1 \delta_2}$ ，得到

$$\frac{1}{2} \sum_{j, \delta_1, \delta_2} g^{\delta_1 \delta_2} z_{j; \delta_1}^{(L)} z_{j; \delta_2}^{(L)} \Big|_{z_{\mathcal{A}}=y_{\mathcal{A}}} = \text{常数} + \frac{1}{2} \sum_{j, \dot{\beta}_1, \dot{\beta}_2} \mathbb{G}^{\dot{\beta}_1 \dot{\beta}_2} (z_{j; \dot{\beta}_1}^{(L)} - m_{j; \dot{\beta}_1}) (z_{j; \dot{\beta}_2}^{(L)} - m_{j; \dot{\beta}_2}), \quad (6.80)$$

朴素后验均值为

$$m_{i; \dot{\beta}} = \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} g_{\dot{\beta} \tilde{\alpha}_1} \tilde{g}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2}, \quad (6.81)$$

而朴素后验协方差为

$$\mathbb{G}_{\dot{\beta}_1 \dot{\beta}_2} = g_{\dot{\beta}_1 \dot{\beta}_2} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} g_{\dot{\beta}_1 \tilde{\alpha}_3} \tilde{g}^{\tilde{\alpha}_3 \tilde{\alpha}_4} g_{\tilde{\alpha}_4 \dot{\beta}_2}. \quad (6.82)$$

之所以称为朴素，是因为作用量的四次项还会带来额外修正. 以下以后验均值为例明确展示这一机制. 给定观测到的真实输出 $y_{i; \tilde{\alpha}}$ ，且二次项 (6.80) 以朴素后验均值 $m_{i; \dot{\beta}}$ 为中心，自然可把中心取为

$$\Phi_{i; \delta} \equiv (y_{i; \tilde{\alpha}}, m_{i; \dot{\beta}}) = \left(y_{i; \tilde{\alpha}}, \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} g_{\dot{\beta} \tilde{\alpha}_1} \tilde{g}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2} \right), \quad (6.83)$$

及涨落 $w_{i; \dot{\beta}} = z_{i; \dot{\beta}}^{(L)} - m_{i; \dot{\beta}}$ ，于是

$$z_{i; \delta}^{(L)} \rightarrow (y_{i; \tilde{\alpha}}, m_{i; \dot{\beta}} + w_{i; \dot{\beta}}) = \Phi_{i; \delta} + (0, w_{i; \dot{\beta}}). \quad (6.84)$$

将此分解代入作用量 (6.79)，即可显式呈现子样本划分 $\mathcal{D} = \mathcal{A} \cup \mathcal{B}$. 用这一涨落表示，二次项 (6.80) 成为

$$\text{常数} + \frac{1}{2} \sum_{j=1}^{n_L} \sum_{\dot{\beta}_1, \dot{\beta}_2 \in \mathcal{B}} \mathbb{G}^{\dot{\beta}_1 \dot{\beta}_2} w_{j; \dot{\beta}_1} w_{j; \dot{\beta}_2}, \quad (6.85)$$

而四次项展开为

$$\begin{aligned}
\mathcal{Q}(w) = & \text{常数} + \frac{4}{8} \sum_{j, \dot{\beta}_1} w_{j; \dot{\beta}_1} \sum_{k, \delta_1, \delta_2, \delta_3} v^{(\dot{\beta}_1 \delta_1)(\delta_2 \delta_3)} \Phi_{j; \delta_1} \Phi_{k; \delta_2} \Phi_{k; \delta_3} \\
& + \frac{2}{8} \sum_{j, \dot{\beta}_1, \dot{\beta}_2} w_{j; \dot{\beta}_1} w_{j; \dot{\beta}_2} \sum_{k, \delta_1, \delta_2} v^{(\dot{\beta}_1 \dot{\beta}_2)(\delta_1 \delta_2)} \Phi_{k; \delta_1} \Phi_{k; \delta_2} \\
& + \frac{4}{8} \sum_{j, k, \dot{\beta}_1, \dot{\beta}_2} w_{j; \dot{\beta}_1} w_{k; \dot{\beta}_2} \sum_{\delta_1, \delta_2} v^{(\dot{\beta}_1 \delta_1)(\dot{\beta}_2 \delta_2)} \Phi_{j; \delta_1} \Phi_{k; \delta_2} \\
& + \frac{4}{8} \sum_{j, k, \dot{\beta}_1, \dot{\beta}_2, \dot{\beta}_3} w_{j; \dot{\beta}_1} w_{j; \dot{\beta}_2} w_{k; \dot{\beta}_3} \sum_{\delta_1} v^{(\dot{\beta}_1 \dot{\beta}_2)(\dot{\beta}_3 \delta_1)} \Phi_{k; \delta_1} \\
& + \frac{1}{8} \sum_{j, k, \dot{\beta}_1, \dots, \dot{\beta}_4} w_{j; \dot{\beta}_1} w_{j; \dot{\beta}_2} w_{k; \dot{\beta}_3} w_{k; \dot{\beta}_4} v^{(\dot{\beta}_1 \dot{\beta}_2)(\dot{\beta}_3 \dot{\beta}_4)}. \tag{6.86}
\end{aligned}$$

因此可由下列期望确定真正的后验均值：

$$\begin{aligned}
\int dz_{\mathcal{B}}^{(L)} p(z_{\mathcal{B}}^{(L)} | y_{\mathcal{A}}) z_{i; \dot{\beta}}^{(L)} &= \int dz_{\mathcal{B}}^{(L)} \frac{p(y_{\mathcal{A}}, z_{\mathcal{B}}^{(L)})}{p(y_{\mathcal{A}})} z_{i; \dot{\beta}}^{(L)} \\
&= m_{i; \dot{\beta}} + \int dw_{\mathcal{B}} \frac{p(y_{\mathcal{A}}, m_{\mathcal{B}} + w_{\mathcal{B}})}{p(y_{\mathcal{A}})} w_{i; \dot{\beta}} \\
&= m_{i; \dot{\beta}} + \frac{\langle\langle w_{i; \dot{\beta}} e^{\mathcal{Q}(w)} \rangle\rangle_{\mathbb{G}}}{\langle\langle e^{\mathcal{Q}(w)} \rangle\rangle_{\mathbb{G}}} \\
&= m_{i; \dot{\beta}} + \frac{\langle\langle w_{i; \dot{\beta}} [1 + \mathcal{Q}(w)] \rangle\rangle_{\mathbb{G}}}{\langle\langle 1 + \mathcal{Q}(w) \rangle\rangle_{\mathbb{G}}} + O(v^2) \\
&= m_{i; \dot{\beta}} + \langle\langle w_{i; \dot{\beta}} \mathcal{Q}(w) \rangle\rangle_{\mathbb{G}} + O(v^2). \tag{6.87}
\end{aligned}$$

第一行使用后验的贝叶斯法则 (6.25)；第二行在两处代入分解 (6.84)；第三行分离四次项，把后验期望写成关于朴素后验协方差 $\mathbb{G}$ 的高斯期望除以归一化；第四行展开指数；最后使用高斯期望下 $\langle\langle w_{i; \dot{\beta}} \rangle\rangle_{\mathbb{G}} = 0$ 。再代入式 (6.86) 并进行 Wick 收缩，即可计算剩余的高斯期望：

$$\begin{aligned}
m_{i; \dot{\beta}} + \frac{1}{2} \sum_{\dot{\beta}_1} \mathbb{G}_{\dot{\beta} \dot{\beta}_1} \sum_{k, \delta_1, \delta_2, \delta_3} v^{(\dot{\beta}_1 \delta_1)(\delta_2 \delta_3)} \Phi_{i; \delta_1} \Phi_{k; \delta_2} \Phi_{k; \delta_3} \\
+ \frac{1}{2} \sum_{\dot{\beta}_1, \dot{\beta}_2, \dot{\beta}_3} (n_L \mathbb{G}_{\dot{\beta}_1 \dot{\beta}_2} \mathbb{G}_{\dot{\beta} \dot{\beta}_3} + 2 \mathbb{G}_{\dot{\beta} \dot{\beta}_1} \mathbb{G}_{\dot{\beta}_2 \dot{\beta}_3}) \sum_{\delta_1} v^{(\dot{\beta}_1 \dot{\beta}_2)(\dot{\beta}_3 \delta_1)} \Phi_{i; \delta_1}. \tag{6.88}
\end{aligned}$$

故朴素后验均值 (6.81) 受到多个依赖于 v 的项修正。为从这个复杂表达式中提取一些物理，注意由定义 (6.83)， $\Phi_{i; \delta}$ 的第 i 个分量依赖观测 $y_{i; \bar{\alpha}}$ 的第 i 个分量。因此，含 $\sum_k \Phi_{i; \delta_1} \Phi_{k; \delta_2} \Phi_{k; \delta_3}$ 的项确实纳入了真实输出所有分量的信息；当 $i \neq k$ 时，观测输出第 k 个分量的信息会影响第 i 个分量的后验均值预测。因而

$$p(z_{i; \mathcal{B}}^{(L)}, z_{k; \mathcal{B}}^{(L)} | y_{i; \mathcal{A}}, y_{k; \mathcal{A}}) \neq p(z_{i; \mathcal{B}}^{(L)} | y_{i; \mathcal{A}}) p(z_{k; \mathcal{B}}^{(L)} | y_{k; \mathcal{A}}). \tag{6.89}$$

后验分布的这一性质源自第 6.4.1 节所讨论的有限宽先验中非平凡的一起放电归纳偏置 $p(z_i^{(L)}|z_k^{(L)})$. 后验输出分量间的依赖关系 (6.89) 标志着后验信念学会了连接在一起；下一节重新考察表征学习时，还会看到这一点的进一步体现。

在继续之前，还应处理实际问题. 实际上，求值贝叶斯学习的有限宽预测 (6.87)，在计算上甚至比无限宽情形更不可行. 特别地，求四次耦合时，首先要表示四点顶角——一个 $N_A \times N_A \times N_A \times N_A$ 维张量——然后再令其与逆核作多重收缩. 因而计算成本和内存需求都随观测数量、即数据集 $\mathcal{A}$ 的大小骇人地增长. 不过请不要恐慌：我们已经越来越接近揭示基于梯度的学习如何在有限宽下解决所有这些实际困难了。

6.4.3 表征学习的存在

有限宽后验均值预测的各个分量能够纳入其他分量观测所提供的信息，这暗示这些观测或许也可用于在隐藏层中建立表征. 这里将证明，非零的层间相互作用确实会直接导致表征学习。

与无限宽下的对应小节（第 6.3.3 节）类似，可以在给定观测 y_A 后，考察完整样本集 $\mathcal{D}$ 上倒数第二层 $\ell = L - 1$ 的后验分布，从而研究表征学习. 特别地，为说明倒数第二层表征的特征如何演化，我们要计算倒数第二层可观测量 $\mathcal{O}(z_D^{(L-1)})$ 的后验期望相对于先验期望的变化

$$\overline{d\mathcal{O}} \equiv \int dz_D^{(L-1)} p(z_D^{(L-1)}|y_A) \mathcal{O}(z_D^{(L-1)}) - \int dz_D^{(L-1)} p(z_D^{(L-1)}) \mathcal{O}(z_D^{(L-1)}) . \quad (6.90)$$

这里的 $p(z_D^{(L-1)})$ 和 $p(z_D^{(L-1)}|y_A)$ 分别是先验分布和后验分布. 在无限宽极限中，这一期望差严格为零，因为倒数第二层的后验与先验完全相等，见式 (6.71). 相反，非零的差意味着在作出观测 y_A 之后，倒数第二层的预激活量发生了更新. 这种更新正是表征学习的直接体现。

仍由贝叶斯法则，给定观测 y_A 后倒数第二层预激活量 $z_D^{(L-1)}$ 的后验分布可写为

$$p(z_D^{(L-1)}|y_A) = \frac{p(y_A|z_D^{(L-1)}) p(z_D^{(L-1)})}{p(y_A)} . \quad (6.91)$$

和之前一样，似然 $p(y_A|z_D^{(L-1)})$ 是层间条件分布 $p(z_A^{(L)}|z_D^{(L-1)})$ 在观测集 $z_A^{(L)} \rightarrow y_A$ 上的取值. 利用后验表达式 (6.91)，贝叶斯学习后的更新 $\overline{d\mathcal{O}}$ 可写为

$$\overline{d\mathcal{O}} = \mathbb{E} \left[\frac{p(y_A|z_D^{(L-1)})}{p(y_A)} \mathcal{O}(z_D^{(L-1)}) \right] - \mathbb{E} [\mathcal{O}(z_D^{(L-1)})] . \quad (6.92)$$

一如既往，完整期望 $\mathbb{E}[\cdot]$ 要对先验或初始化分布 $p(z_D^{(L-1)})$ 求值；所有学习效应都像上式那样由其他因子的插入显式表示。

现在来确定这一插入，即似然与证据之比

$$\frac{p(y_A|z_D^{(L-1)})}{p(y_A)} , \quad (6.93)$$

如何依赖预激活量 $z_{\mathcal{D}}^{(L-1)}$. 在无限宽例子中已经指出, 式 (4.69) 给出了这一似然, 即层间条件分布. 在当前语境和记号下, 似然为

$$p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)}) = \frac{1}{\sqrt{|2\pi\widehat{G}^{(L)}|^{n_L}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \widehat{G}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2}\right), \quad (6.94)$$

其中随机度量 $\widehat{G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} = \widehat{G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}(z_{\mathcal{A}}^{(L-1)})$ 显式依赖倒数第二层的预激活量 $z_{i;\mathcal{A}}^{(L-1)}$.¹²⁵ 因而, 随机度量在此充当耦合, 诱导第 $(L-1)$ 层预激活量与观测 $y_{\mathcal{A}}$ 之间的层间相互作用. 正如下文所见, 这使 $z_{\mathcal{D}}^{(L-1)}$ 的更新后分布依赖 $y_{\mathcal{A}}$.

此时应已相当熟悉: 可把随机度量分解为均值和涨落

$$\widehat{G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \equiv G_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} + \widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}. \quad (6.95)$$

用此分解, 可以像式 (4.56) 和式 (4.57) 那样, 以 Schwinger–Dyson 的方式对似然 (6.94) 作 Taylor 展开. 在首个非平凡阶, 似然与证据之比 (6.93) 为

$$\begin{aligned} & \frac{p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)})}{p(y_{\mathcal{A}})} \\ &= \frac{1}{p(y_{\mathcal{A}}) \sqrt{|2\pi G^{(L)}|^{n_L}}} \left[1 + \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} G_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} G_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \right. \\ & \quad \left. \times \sum_{i=1}^{n_L} \left(y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4} - G_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) + O(\Delta^2) \right], \end{aligned} \quad (6.96)$$

方括号之前的因子相对于变量 $z_{\mathcal{D}}^{(L-1)}$ 是常数, 因此求更新 $\overline{d\mathcal{O}}$ (6.92) 所需的全部相关依赖都隐含在度量涨落 $\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$ 中. 因而, 任何可观测量的后验期望——即式 (6.92) 中的第一个期望——都可用方括号内的量作权重来积分, 只要再除以同一量对“1”的积分, 以保证正确归一化. 运用这一已很熟悉的技巧, 后验期望可改写为

$$\begin{aligned} & \frac{\mathbb{E} \left\{ \mathcal{O}(z_{\mathcal{D}}^{(L-1)}) \left[1 + \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} G_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} G_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i \left(y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4} - G_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) + O(\Delta^2) \right] \right\}}{\mathbb{E} \left[1 + \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} G_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} G_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i \left(y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4} - G_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) + O(\Delta^2) \right]} \\ &= \mathbb{E} \left[\mathcal{O}(z_{\mathcal{D}}^{(L-1)}) \right] \\ & \quad + \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \mathbb{E} \left[\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \mathcal{O}(z_{\mathcal{D}}^{(L-1)}) \right] G_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} G_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i \left(y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4} - G_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (6.97)$$

¹²⁵ 严格地说, 这里的随机度量应记为 $\widehat{\widetilde{G}}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$, 以表明我们关注的是定义在 $\mathcal{D}$ 上的完整随机度量 $\widehat{G}_{\delta_1 \delta_2}^{(L)}$ 的 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 子矩阵. 式 (6.94) 中出现的是这一子矩阵 $\widehat{\widetilde{G}}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$ 的矩阵逆, 而不是完整矩阵 $\widehat{G}_{\delta_1 \delta_2}^{(L)}$ 的逆的 $(\tilde{\alpha}_1, \tilde{\alpha}_2)$ 分块. 带帽又带波浪的记号实在荒唐, 而我们在记号上已经不堪重负; 只要读者答应牢记这一警告, 我们就暂时省略波浪号, 给所有人省些麻烦.

具体操作的细节藏在这条脚注里.¹²⁶ 第一项正是先验期望, 而第二项表示更新 $\overline{d\mathcal{O}}$ (6.90). 最后, 只保留 $1/n$ 阶的领先有限宽修正, 并恢复波浪号以正确表示仅定义在 $\mathcal{A}$ 上的子矩阵, 便得到任意倒数第二层可观测量在 $1/n$ 的首个非平凡阶上的一般更新公式:

$$\overline{d\mathcal{O}} = \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \mathbb{E} \left[\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \right] \tilde{K}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{K}_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i^{n_L} \left(y_{i; \tilde{\alpha}_3} y_{i; \tilde{\alpha}_4} - \tilde{K}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right). \quad (6.99)$$

再次提醒, 式 (6.99) 中的 $\mathbb{E}[\cdot]$ 要对先验分布 $p(z_{\mathcal{D}}^{(L-1)})$ 求值. 还应注意, 更新 (6.99) 中唯一的期望正是随机度量与可观测量的协方差:

$$\mathbb{E} \left[\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \right] = \mathbb{E} \left[\widehat{G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \right] - \mathbb{E} \left[\widehat{G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \right] \mathbb{E} \left[\mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \right]. \quad (6.100)$$

正如那条“地毯”脚注中所论, 对于一般的量级为一的可观测量, 这一协方差受到 $1/n$ 抑制, 但并不为零. 因此, 在大而有限的宽度 ($1 \ll n < \infty$) 下, 这些可观测量会得到更新: 表征得以学习.

为了看清其工作方式, 考虑一个具体例子. 最简单的可观测量是激活量的平均范数

$$\mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \equiv \frac{1}{n_{L-1}} \sum_{j=1}^{n_{L-1}} \sigma_{j; \delta_1}^{(L-1)} \sigma_{j; \delta_2}^{(L-1)}, \quad (6.101)$$

它可分解为均值和涨落

$$\mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) = \mathbb{E} \left[\mathcal{O} \left(z_{\mathcal{D}}^{(L-1)} \right) \right] + \frac{1}{C_W^{(L)}} \widehat{\Delta G}_{\delta_1 \delta_2}^{(L)}, \quad (6.102)$$

这里还用到了度量涨落的显式形式 (4.74)

$$\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} = C_W^{(L)} \frac{1}{n_{L-1}} \sum_{j=1}^{n_{L-1}} \left(\sigma_{j; \tilde{\alpha}_1}^{(L-1)} \sigma_{j; \tilde{\alpha}_2}^{(L-1)} - \mathbb{E} \left[\sigma_{j; \tilde{\alpha}_1}^{(L-1)} \sigma_{j; \tilde{\alpha}_2}^{(L-1)} \right] \right). \quad (6.103)$$

把它代入领先有限宽更新公式 (6.99), 得到

$$\begin{aligned} \overline{d\mathcal{O}} &= \frac{1}{2C_W^{(L)}} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \mathbb{E} \left[\widehat{\Delta G}_{\delta_1 \delta_2}^{(L)} \widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \right] \tilde{K}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{K}_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i \left(y_{i; \tilde{\alpha}_3} y_{i; \tilde{\alpha}_4} - \tilde{K}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) \\ &= \frac{1}{2n_{L-1} C_W^{(L)}} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} V_{(\delta_1 \delta_2)(\tilde{\alpha}_1 \tilde{\alpha}_2)}^{(L)} \tilde{K}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{K}_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i \left(y_{i; \tilde{\alpha}_3} y_{i; \tilde{\alpha}_4} - \tilde{K}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right). \end{aligned} \quad (6.104)$$

¹²⁶ 正文把额外的 $O(\Delta^2)$ 项视为 $O(1/n^2)$, 其理由藏在地毯下面. 掀开地毯一角, 先把似然与证据之比 (6.96) 示意地写成 常数 $\times [1 + \sharp_1 \Delta G + \sharp_2 (\Delta G)^2 + O(\Delta^3)]$. 后验期望于是成为

$$\begin{aligned} \frac{\mathbb{E} \left\{ \mathcal{O} [1 + \sharp_1 \Delta G + \sharp_2 (\Delta G)^2 + O(\Delta^3)] \right\}}{\mathbb{E} [1 + \sharp_1 \Delta G + \sharp_2 (\Delta G)^2 + O(\Delta^3)]} &= \frac{\mathbb{E} [\mathcal{O}] + \sharp_1 \mathbb{E} [\mathcal{O} \Delta G] + \sharp_2 \mathbb{E} [(\Delta G)^2 \mathcal{O}] + O(1/n^2)}{1 + \sharp_2 \mathbb{E} [(\Delta G)^2] + O(1/n^2)} \\ &= \mathbb{E} [\mathcal{O}] + \sharp_1 \mathbb{E} [\mathcal{O} \Delta G] + \sharp_2 \left\{ \mathbb{E} [(\Delta G)^2 \mathcal{O}] - \mathbb{E} [(\Delta G)^2] \mathbb{E} [\mathcal{O}] \right\} + O(1/n^2). \end{aligned} \quad (6.98)$$

再把可观测量分解为均值与涨落 $\mathcal{O} = \mathbb{E}[\mathcal{O}] + \Delta \mathcal{O}$, 便可看到正比于 $\sharp_2$ 的项是 $\mathbb{E} [O(\Delta^3)] = O(1/n^2)$, 因而可以忽略; 但领先的有限宽修正不可忽略: $\sharp_1 \mathbb{E} [\mathcal{O} \Delta G] = \sharp_1 \mathbb{E} [\Delta \mathcal{O} \Delta G] = O(1/n)$.

从第一行到第二行，使用了四点顶角由度量涨落二点函数定义的关系 (4.76). 由于该顶角刻画输出分布的非高斯性，这里明确看到相互作用如何介导倒数第二层激活量的更新. 此外，领先因子 $1/n_{L-1}$ 清楚表明这一更新是有限宽效应. 最后一个括号中的项还表明，更新显式依赖输出观测 $y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4}$ 与其先验期望 $\mathbb{E} \left[z_{i;\tilde{\alpha}_3}^{(L)} z_{i;\tilde{\alpha}_4}^{(L)} \right] \equiv \tilde{K}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} + O(1/n)$ 之差. 这意味着观测确实向后传播，从而诱导隐藏层表征发生变化.¹²⁷

这种有限宽下贝叶斯表征学习的分析或许没有实际用途，但它会成为一份在理论上有用的蓝图，用来研究第 11 节中有限宽下基于梯度的学习所发生的类似表征学习. 至此，关于基于梯度学习的种种暗示已经连本带利地积累起来；你一定迫不及待地想翻到下一章了！

¹²⁷ 这种向后传播，或者不妨称为反向传播，还会继续进入更浅的隐藏层. 不过，在第 $(L-2)$ 层中，后验更新为 $O(1/n^2)$ 阶. 直观上这是合理的：倒数第二层 $(L-1)$ 中的表征变化已经受到一个 $1/n$ 因子的抑制；向后进入第 $(L-2)$ 层时，层间相互作用的 $1/n$ 抑制又使其进一步减小.

在数学上，可以把第 $(L-2)$ 层可观测量 $\mathcal{O}(z_{\mathcal{D}}^{(L-2)})$ 的更新写成

$$\bar{d}\mathcal{O} \equiv \int dz_{\mathcal{D}}^{(L-2)} p(z_{\mathcal{D}}^{(L-2)} | y_{\mathcal{A}}) \mathcal{O}(z_{\mathcal{D}}^{(L-2)}) - \int dz_{\mathcal{D}}^{(L-2)} p(z_{\mathcal{D}}^{(L-2)}) \mathcal{O}(z_{\mathcal{D}}^{(L-2)}). \quad (6.105)$$

借助贝叶斯法则、求和法则和乘积法则，上式中的后验插入可由下列边缘化给出：

$$p(z_{\mathcal{D}}^{(L-2)} | y_{\mathcal{A}}) = \frac{p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-2)}) p(z_{\mathcal{D}}^{(L-2)})}{p(y_{\mathcal{A}})} = \int dz_{\mathcal{D}}^{(L-1)} \frac{p(y_{\mathcal{A}} | z_{\mathcal{D}}^{(L-1)})}{p(y_{\mathcal{A}})} p(z_{\mathcal{D}}^{(L-1)}, z_{\mathcal{D}}^{(L-2)}). \quad (6.106)$$

从这里出发，重复导出倒数第二层更新公式 (6.99) 的同一套操作，得到

$$\bar{d}\mathcal{O} = \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \mathbb{E} \left[\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}(z_{\mathcal{D}}^{(L-1)}) \mathcal{O}(z_{\mathcal{D}}^{(L-2)}) \right] \tilde{K}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{K}_{(L)}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \sum_i^{n_L} \left(y_{i;\tilde{\alpha}_3} y_{i;\tilde{\alpha}_4} - \tilde{K}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right) + O\left(\frac{1}{n^2}\right). \quad (6.107)$$

因此，要证明这一变化为 $O(1/n^2)$ 阶，就需要证明层间相关

$$\mathbb{E} \left[\widehat{\Delta G}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}(z_{\mathcal{D}}^{(L-1)}) \mathcal{O}(z_{\mathcal{D}}^{(L-2)}) \right], \quad (6.108)$$

是 $O(1/n^2)$ 阶. 最快的证明要留到未来：先在 $\ell = L-2$ 时应用公式 (8.54)，再施展式 (8.70) 附近的相关技巧. 如果愿意接受挑战，请向后翻到式 (8.70)，在旁边写下注记，提醒自己返回第 6.4.3 节的脚注 127. 剧透警告：最终确应发现式 (6.108) 为 $O(1/n^2)$ 阶.

第 7 章

基于梯度的学习

当然，这就像是说，力学教科书中出现的牛顿第二定律 $F = ma$ ，不过是对所谓“力”的定义。严格来说这没有错，但我们所处的语境包含一个隐含承诺：当有人写下这个式子时... 他接下来会给出力的定律，而不是，例如，给出某个涉及位置对时间的第 17 阶导数的量之定律。

Sidney Coleman, 在其 Dirac 讲座“当面讲量子力学”中 [56].

上一章中，我们讨论了作为一种学习算法的贝叶斯推断；它自然承接了我们对初始化网络的研究。从一个带参数——权重与偏置——的神经网络架构描述出发，我们把这些参数积掉，得到预激活 $z^{(\ell)}(x)$ 随层与输入样本的分布；其中尤其包括输出分布 $p(z^{(L)}(x))$ 。我们把它解释为此类模型系综上的先验分布，然后说明贝叶斯法则的逻辑如何把先验演化为以观测数据为条件的后验分布。尽管贝叶斯推断在理论上很优美，随着取条件的数据样本数增加，其朴素实现很快就在计算上变得不可处理。

退后一步看，这套设置其实有些奇怪。一旦求出输出分布，实际网络本身就被丢弃了，因为参数早已积掉。贝叶斯推断只关心模型的输出分布，所以推断的起点其实可以是任何模型系综；它根本不是专为神经网络定制的。那么，我们为何费尽周折从神经网络模型出发？一开始又怎能知道这些模型是一种良好的抽象？

深度神经网络令人振奋，是因为它们出乎意料地好用。我们之所以知道这一点，是因为实践中这类网络会被显式地训练，并用于完成有用的任务。最常见的学习方式，是通过梯度下降之类基于梯度的优化程序反复更新模型参数。

具体而言，基于梯度的学习算法通过优化一个辅助损失函数，可以高效处理大量训练数据；该函数直接把网络输出 $f(x; \theta) \equiv z^{(L)}(x)$ 与某个期望结果或标签比较。这一优化程序只从初始化分布中抽取一组网络参数，因而得到的是一个针对目标任务训练的网络，而不是完整的网络系综。这样，基于梯度的学习方法虽然由于缺乏系综而无法表达对预测的置信度，却以数据效率和易扩展性弥补了这一缺陷。

由于梯度下降要显式更新模型参数，第一步便是把它们重新找回来（无论变量被积掉后究竟去了哪里）。在监督学习中，模型参数的调整量正比于函数逼近误差与模型输出对参数的梯度之积。这种分解促使我们研究神经正切核（NTK）¹²⁸。简言之，只要使用梯度下降来优化一个为函数逼近评分的辅助损失，NTK 就是一类控制可观测量训练动力学的哈密顿量。如 §10、§11 和 §∞ 所详述，理解给定神经网络架构的 NTK，将使我们能够有效描述该模型中基于梯度的学习。

¹²⁸NTK 最早由 Jacot 等人在无限宽网络语境下的奠基性工作 [57] 中识别出来。

本章先在 §7.1 简介监督学习，随后在 §7.2 讨论梯度下降，重点从很一般的角度说明 NTK 如何在监督学习中出现。下一章中，我们将利用与 §4 相同的逐层 RG 流技术，把 NTK 纳入深度学习有效理论。

7.1 监督学习

神经网络最擅长的基本建模任务之一称为**监督学习**。给定**数据分布** $p(x, y) = p(y|x)p(x)$ ，目标是：对于从该分布联合抽取的任意一对数据，在给定输入 x 时预测**标签** y 。¹²⁹ 更准确地说，模型试图学习条件分布 $p(y|x)$ ，所得模型有时称为**判别模型**。在一个典型的计算机视觉例子中，我们可能想按照手写数字图像 x_δ 的字面值 $y_\delta = 3$ ，把“3”的图像**分类**。又例如在自然语言处理中，给定一个包含单词 $x_\delta = \text{cat}$ 的句子，我们可能想识别其词性为 $y_\delta = \text{noun}$ 。概率模型对 $p(y|x)$ 学得越好，就越能准确预测新输入样本 x 的真实标签 y 。生成这类数据集通常需要人类标注者为输入添加标签，“监督学习”因此得名。

在这一设置中，监督学习模型输出预测 $z(x_\delta; \theta)$ 。该记号强调模型输出既是输入 x_δ 的函数，也是某些可调参数 θ 的函数。在神经网络的函数逼近语境中，这一点应当已经很熟悉：模型参数由偏置和权重组成。

如 §2.3 所述，模型参数从一个易于采样的参数先验分布中抽取；在基于梯度的学习中，它也称为初始化分布。重要的是，该参数分布对数据分布一无所知。因而，为了使模型作出良好预测，必须以某种方式调整参数。其实，这只是 §2.1 所讨论函数逼近的一个具体应用，其中要逼近的函数是条件分布 $p(y|x)$ 。

在理解如何调整或拟合模型参数之前，必须先说明“作出良好预测”是什么意思。对从数据分布 $p(x, y)$ 抽取的典型输入 x_δ 和标签 y_δ ，我们希望模型输出 $z(x_\delta; \theta)$ 平均而言尽可能接近标签 y_δ 。为衡量这种接近程度，对一组预测-标签对，需要定义辅助的目标函数，也就是**损失**

$$\mathcal{L}(z(x_\delta; \theta), y_\delta), \quad (7.1)$$

其性质是： $z(x_\delta; \theta)$ 越接近 y_δ ，函数值越低。一种非常直观的选择是均方误差损失 (6.17)，

$$\mathcal{L}_{\text{MSE}}(z(x_\delta; \theta), y_\delta) \equiv \frac{1}{2} [z(x_\delta; \theta) - y_\delta]^2, \quad (7.2)$$

它显然具有所需性质，尽管这不是深度学习中最常见的选择。损失的具体形式不影响本章其余内容。

有了损失函数，训练的目标便是调整模型参数，使尽可能多的输入-标签对的损失最小。理想情况下，我们希望最小化在整个数据分布上平均的损失，

$$\mathbb{E}[\mathcal{L}(\theta)] = \int dx dy p(x, y) \mathcal{L}(z(x; \theta), y). \quad (7.3)$$

但我们几乎从来无法获得数据分布 $p(x, y)$ 的解析形式，因此实践中这需要抽取无穷多个输入-标签对。作为整个损失 (7.3) 的替代，我们抽取大量但有限的样本对 $(x_{\tilde{\alpha}}, y_{\tilde{\alpha}})_{\tilde{\alpha} \in \mathcal{A}}$ ，

¹²⁹ 本节隐去输入 x_δ 、标签 y_δ 和模型输出 $z(x_\delta; \theta)$ 的向量指标，同时经常保留样本指标 $\delta \in \mathcal{D}$ 。

并尝试最小化

$$\mathcal{L}_{\mathcal{A}}(\theta) \equiv \sum_{\tilde{\alpha} \in \mathcal{A}} \mathcal{L}(z(x_{\tilde{\alpha}}; \theta), y_{\tilde{\alpha}}). \quad (7.4)$$

该样本集合 $\mathcal{A}$ 称为**训练集**，损失估计 (7.4) 称为**训练损失**。这里沿用 §6 的样本指标记法：训练集输入 $\tilde{\alpha} \in \mathcal{A}$ 用带波浪号的 alpha，普通输入 $\delta \in \mathcal{D}$ 用不带修饰的 delta，稍后测试集输入 $\dot{\beta} \in \mathcal{B}$ 则用带点的 beta。¹³⁰ 为训练模型，我们试图寻找使训练损失最小的模型参数构型

$$\theta^* = \arg \min_{\theta} \mathcal{L}_{\mathcal{A}}(\theta) = \arg \min_{\theta} \left[\sum_{\tilde{\alpha} \in \mathcal{A}} \mathcal{L}(z(x_{\tilde{\alpha}}; \theta), y_{\tilde{\alpha}}) \right]. \quad (7.6)$$

下一节将介绍实现该目标的梯度下降算法。

把训练损失 (7.4) 的最小化定为优化问题后，仍须牢记：监督学习的真正目标，是按 (7.3) 的意义最小化整个数据分布上的损失。换言之，问题不在于模型能否记住训练集中的所有输入-标签对，而在于它能否把预测泛化到训练期间未见过的其他输入-标签对。因而，人们可能担心训练集在抽样数据分布时是否存在偏差，或者某个特定样本集合是否具有较大方差。

为了显式评估模型的**泛化**性质，通常会单独留出输入-标签样本集合 $(x_{\dot{\beta}}, y_{\dot{\beta}})_{\dot{\beta} \in \mathcal{B}}$ ，称为**测试集**；它只在训练完成后用于评估模型。只要训练集 $\mathcal{A}$ 能够代表完整数据分布 $p(x, y)$ ，降低训练损失往往也会降低整个损失 (7.3)；后者由测试损失 $\mathcal{L}_{\mathcal{B}}$ 估计。我们将在 §10 直接讨论这一问题。

7.2 梯度下降与函数逼近

考察训练损失最小化 (7.6)，可见学习是一个复杂的优化问题。最朴素地说，为寻找函数极值，微积分要求对训练损失求导，并找出使所得表达式为零的自变量值：

$$0 = \left. \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\mu}} \right|_{\theta=\theta^*}. \quad (7.7)$$

遗憾的是，只有在特殊情形下，例如损失关于模型参数为二次函数时，才能精确求解该方程。实践者通常不去解析地求最小值，而是采用迭代过程，使损失逐步接近最小值。

¹³⁰训练损失 (7.4) 的定义与期望损失 (7.3) 的定义稍有抵牾。期望损失是强度量，而训练损失是广延量，随训练集大小 $N_{\mathcal{A}} \equiv |\mathcal{A}|$ 线性缩放。后一种选择与 §6.2.1 中把 MLE 作为贝叶斯模型拟合近似方法时对损失 (6.17) 的初始定义一致。在贝叶斯框架中，损失的广延性很自然：随着观测输入-输出对的数目 $N_{\mathcal{A}}$ 增大，我们希望似然压倒先验。因而，本书自然地遵循这一约定。（更准确地说，广延损失 (6.17) 可称为均方误差。）

不过，从非贝叶斯视角看，训练损失通常定义为

$$\mathcal{L}_{\mathcal{A}}(\theta) \equiv \frac{1}{|\mathcal{A}|} \sum_{\tilde{\alpha} \in \mathcal{A}} \mathcal{L}(z(x_{\tilde{\alpha}}; \theta), y_{\tilde{\alpha}}), \quad (7.5)$$

它与期望损失 (7.3) 更对应。在基于梯度的学习中，整体归一化总能吸收到下一节将引入的全局学习率 η 的重新定义中，因此后一种定义 (7.5) 的唯一优势，在我们看来只是损失与其名称更相符。

梯度下降正是可以最小化训练损失 (7.4) 这类非平凡函数的方法之一, 因而很自然地成为模型拟合的候选算法. 该算法计算损失的梯度, 并沿梯度的负方向反复更新模型参数:

$$\theta_{\mu}(t+1) = \theta_{\mu}(t) - \eta \left. \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\mu}} \right|_{\theta_{\mu}=\theta_{\mu}(t)}, \quad (7.8)$$

其中 t 记录迭代训练过程的步数, 按惯例 $t=0$ 是初始化点. 这里, η 是称为**学习率**的正**训练超参数**, 控制在参数空间中迈出的步长. 梯度下降的计算成本随数据集 $\mathcal{A}$ 的大小线性缩放, 因为只需对每个样本计算梯度再求和.

只要学习率足够小, 更新 (7.8) 就保证降低训练损失 $\mathcal{L}_{\mathcal{A}}$. 为说明这一点, 在当前参数值 $\theta(t)$ 附近对训练损失作泰勒展开, 并计算一次更新后的损失变化:

$$\Delta\mathcal{L}_{\mathcal{A}} \equiv \mathcal{L}_{\mathcal{A}}(\theta(t+1)) - \mathcal{L}_{\mathcal{A}}(\theta(t)) = -\eta \sum_{\mu} \left(\left. \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\mu}} \right|_{\theta=\theta(t)} \right)^2 + O(\eta^2). \quad (7.9)$$

它是平方和的负值, 因而严格为负. 一般而言, 反复执行这些更新最终将达到训练损失的 (至少一个) 局部最小值. 实践中, 梯度下降算法的若干小变体几乎承担了深度学习中的全部训练与优化.¹³¹

张量梯度下降

在一种此类变体中, 把更新 (7.8) 修改为

$$\theta_{\mu}(t+1) = \theta_{\mu}(t) - \eta \sum_{\nu} \lambda_{\mu\nu} \left. \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\nu}} \right|_{\theta=\theta(t)}, \quad (7.11)$$

便可定义更一般的一族学习算法. 其中, 张量 $\lambda_{\mu\nu}$ 是参数空间上的**学习率张量**; 原梯度下降更新 (7.8) 是取 Kronecker delta $\lambda_{\mu\nu} = \delta_{\mu\nu}$ 的特殊情形. 原梯度下降 (7.8) 只有一个全局学习率 η ; 在张量梯度下降 (7.11) 中, 则可通过 $\lambda_{\mu\nu}$ 分别指定梯度的第 ν 个分量 $d\mathcal{L}_{\mathcal{A}}/d\theta_{\nu}$ 如何贡献于第 μ 个参数 θ_{μ} 的更新. 用广义更新 (7.11) 重复关于 η 的同一泰勒展开 (7.9), 得到

$$\Delta\mathcal{L}_{\mathcal{A}} = -\eta \sum_{\mu, \nu} \lambda_{\mu\nu} \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\mu}} \frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\nu}} + O(\eta^2), \quad (7.12)$$

这表明, 只要学习率张量 $\lambda_{\mu\nu}$ 是半正定矩阵, 学习率足够小时训练损失仍几乎必然下降.

¹³¹尤其是, 最流行的学习算法为**随机梯度下降** (SGD). SGD 的更新形式为

$$\theta_{\mu}(t+1) = \theta_{\mu}(t) - \eta \left. \frac{d\mathcal{L}_{\mathcal{S}_t}}{d\theta_{\mu}} \right|_{\theta_{\mu}=\theta_{\mu}(t)}, \quad (7.10)$$

其中 $\mathcal{S}_t$ 是训练集的子集, $\mathcal{S}_t \subset \mathcal{A}$. 每个子集称为小批量或**批量**. 训练按**轮次**组织; 一个轮次就是完整遍历一次训练集. 通常, 在每个轮次中, 训练集被随机地划分成大小相等的子集, 再依次用这些子集估计梯度.

该算法有两项优势: (i) 训练计算成本现在随集合 $\mathcal{S}_t$ 的固定大小, 而非整个训练集 $\mathcal{A}$ 的大小缩放; (ii) 人们认为 SGD 的泛化性质优于梯度下降. 尽管如此, 关于梯度下降所作的几乎全部论述同样适用于随机梯度下降.

神经正切核

此前关于梯度下降的一切论述，同样适用于任何函数的优化。然而，在函数逼近中还存在额外结构：优化目标是模型输出的函数。

为利用这一结构，先注意到，由链式法则，损失的梯度可写成

$$\frac{d\mathcal{L}_{\mathcal{A}}}{d\theta_{\mu}} = \sum_{i=1}^{n_{\text{out}}} \sum_{\tilde{\alpha} \in \mathcal{A}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}}} \frac{dz_{i;\tilde{\alpha}}}{d\theta_{\mu}}, \quad (7.13)$$

所以一次更新后的损失变化 (7.12) 可整齐地分解为

$$\Delta \mathcal{L}_{\mathcal{A}} = -\eta \sum_{i_1, i_2=1}^{n_{\text{out}}} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \left[\frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_1;\tilde{\alpha}_1}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_2;\tilde{\alpha}_2}} \right] \left[\sum_{\mu, \nu} \lambda_{\mu\nu} \frac{dz_{i_1;\tilde{\alpha}_1}}{d\theta_{\mu}} \frac{dz_{i_2;\tilde{\alpha}_2}}{d\theta_{\nu}} \right] + O(\eta^2). \quad (7.14)$$

第一对方括号中的量衡量函数逼近误差。例如，对 MSE 损失 (7.2)，损失关于模型输出的梯度恰好是预测误差：

$$\frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}}} = z_i(x_{\tilde{\alpha}}; \theta) - y_{i;\tilde{\alpha}}. \quad (7.15)$$

更一般地，对其他损失，损失梯度或误差因子

$$\epsilon_{i;\tilde{\alpha}} \equiv \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}}}, \quad (7.16)$$

在模型输出接近标签时很小。合理地说，误差因子越大，更新 (7.13) 越大，损失变化 (7.14) 也越大。第二对方括号中的量称为**神经正切核** (NTK)

$$H_{i_1 i_2; \tilde{\alpha}_1 \tilde{\alpha}_2} \equiv \sum_{\mu, \nu} \lambda_{\mu\nu} \frac{dz_{i_1;\tilde{\alpha}_1}}{d\theta_{\mu}} \frac{dz_{i_2;\tilde{\alpha}_2}}{d\theta_{\nu}}. \quad (7.17)$$

由 (7.17) 可见，NTK 与辅助损失函数无关。

重要的是，NTK 是函数逼近动力学的主要驱动力。更确切地说，它控制的可观测量远比训练损失更一般。考虑任意依赖模型输出的可观测量

$$\mathcal{O}(\theta) \equiv \mathcal{O}\left(z(x_{\delta_1}; \theta), \dots, z(x_{\delta_M}; \theta)\right), \quad (7.18)$$

其中，对某个数据集 $\mathcal{D}$ ，有 $x_{\delta_1}, \dots, x_{\delta_M} \in \mathcal{D}$ 。例如，若 $\mathcal{D}$ 是测试集 $\mathcal{B}$ 且 $\mathcal{O}$ 是损失函数，则该可观测量就是测试损失 $\mathcal{L}_{\mathcal{B}}$ 。除测试损失外，人们也可能想观察输出某个分量的变化 $\mathcal{O} = z_i(x)$ ，或追踪给定输入 x 的不同输出向量分量之间的相关性 $\mathcal{O} = z_i(x)z_j(x)$ 。对任何这类可观测量 (7.18)，一次更新后的变化为

$$\mathcal{O}(\theta(t+1)) - \mathcal{O}(\theta(t)) = -\eta \sum_{i_1, i_2=1}^{n_{\text{out}}} \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{\delta \in \mathcal{D}} \left[\frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_1;\tilde{\alpha}}} \frac{\partial \mathcal{O}}{\partial z_{i_2;\delta}} \right] H_{i_1 i_2; \tilde{\alpha} \delta} + O(\eta^2). \quad (7.19)$$

方括号既包含函数逼近误差，也包含可观测量如何依赖模型输出的具体信息。相比之下，NTK 包含与特定模型有关的全部动力学信息，并且只依赖模型架构和参数。¹³²

¹³²如以上讨论所示，NTK 一般可为任何函数逼近器定义，这意味着它的名称掩盖了真正的普遍性。除了可以反对名称中的“神经”一词，也可以反对其中的“核”一词。由于 NTK 生成可观测量的演化，它更像哈密顿量而不是核；我们将在 §∞.2.2 充分论证这一说法。

把特定样本的特定输出向量分量视为可观测量, 即 $\mathcal{O} = z_i(x_\delta)$, 可以进一步理解梯度下降下的函数逼近动力学. 此时, (7.19) 中 $\mathcal{O}$ 的导数在向量指标和样本指标上都是 Kronecker delta, 演化简化为

$$z_i(x_\delta; \theta(t+1)) - z_i(x_\delta; \theta(t)) = -\eta \sum_{j=1}^{n_{\text{out}}} \sum_{\tilde{\alpha} \in \mathcal{A}} H_{ij; \delta \tilde{\alpha}} \epsilon_{j; \tilde{\alpha}} + O(\eta^2). \quad (7.20)$$

该式说明一次训练更新后模型输出如何变化. 样本 $x_{\tilde{\alpha}}$ 在模型输出分量 j 上的误差因子 $\epsilon_{j; \tilde{\alpha}}$ (7.16), 通过 NTK 分量 $H_{ij; \delta \tilde{\alpha}}$ 影响另一样本 x_δ 上模型输出分量 i 的更新后行为. 正是这种从观察一个样本 $x_{\tilde{\alpha}}$ 来学习另一个样本 x_δ 的能力, 使函数逼近成为可能. NTK 在样本指标上的非对角分量决定模型的泛化行为, 而在向量指标上的非对角分量允许一个特征影响另一特征的训练. 前一性质将在 §10 进一步讨论, 后一性质则见 §∞.

最后顺便指出, 与训练损失 (7.14) 的情形不同, 对一般可观测测量 (7.19), 方括号中的项不一定为正. 足够小的学习率总能使训练损失 $\mathcal{L}_{\mathcal{A}}$ 下降, 但给定可观测测量未必如此. 特别地, 没有任何保证测试损失会下降; 对于过拟合训练集的模型, 测试损失甚至可能增加.

第 8 章

神经正切核的表征群流

人们把事情弄反了，而他们本不该如此——有人说过，而且说得很有道理：每一种成功的物理理论，都会把它的前身整个吞下去。

Sidney Coleman，在同一场 Dirac 讲座“当面讲量子力学”中稍后且稍深入之处 [56].

上一章中，我们把基于梯度的学习作为贝叶斯学习的替代方案引入，并特别关注了梯度下降算法。简言之，梯度下降算法先从先验分布实例化一个网络，再让训练数据反复通过网络以更新模型参数。对任意给定网络，该算法实现直接、运行高效。在实践中，它使事情变得非常容易。

在理论上，它却使事情稍微困难了一些。对贝叶斯先验而言，偏置与权重的初始化分布极为简单，所以在推导输出分布时，我们能够逐层积掉模型参数；此外，大宽度展开还使有限宽网络的贝叶斯后验能够得到解析表达式。相比之下，经梯度下降训练的任意特定网络，其模型参数与输出会形成错综复杂的相关结构。

为了取得进展，首先需要把视角重新转回统计视角。与其关注某个特定网络如何从数据中学习，不如询问一个典型网络在训练时如何表现。如果我们理解梯度下降下的典型行为（即均值），并能控制不同网络实例之间的涨落（即方差），就可以描述实践中使用的基于梯度的学习。

秉持这一统计视角，回顾上一章：梯度下降更新可分解为误差因子与函数逼近因子的乘积。后一因子被称为神经正切核（NTK），它方便地概括了模型参数变化对网络行为的影响。这意味着，训练初期网络可观测量变化的统计由初始化时 NTK 的统计控制。为继续向前推进，本章与下一章的核心工作是显式计算深度 MLP 的这些 NTK 统计；由这些计算所支持的实际神经网络训练分析，将推迟到 §10 与 §∞。

在 §8.0 中，我们将为 NTK 统计的递归计算奠定基础。具体而言，从 MLP 迭代方程，也就是预激活的前向方程出发，推导相应的 NTK 前向方程。该方程是逐层迭代方程，对模型参数的每一个不同实例都成立。（这里还会说明学习率张量应如何随网络宽度缩放；这一要点在实践中常被忽略。）

随后，对不同实例取平均，便可利用前向方程递归计算 NTK 与预激活的联合统计。这里的方法完全对应于 §4 中处理预激活时采用的 RG 流方法。在 §8.1、§8.2 与 §8.3 中，我们将依次确定第一层、第二层以及更深层的 NTK-预激活联合分布序列。

8.0 NTK 的前向方程

如上一章所见，可观测量 $\mathcal{O}(z)$ 在梯度下降下的演化由 NTK 控制，

$$H_{i_1 i_2; \alpha_1 \alpha_2} \equiv \sum_{\mu, \nu} \lambda_{\mu\nu} \frac{dz_{i_1; \alpha_1}}{d\theta_\mu} \frac{dz_{i_2; \alpha_2}}{d\theta_\nu}, \quad (8.1)$$

其中 $\lambda_{\mu\nu}$ 是学习率张量。

专门考虑 MLP 时，可观测量不仅可以依赖网络输出 $z_{i; \alpha} = z_{i; \alpha}^{(L)}$ ，也可以依赖任意层的预激活 $z_{i; \alpha} = z_{i; \alpha}^{(\ell)}$ 。当 $\ell < L$ 时，这类第 ℓ 层可观测量描述网络的隐藏层表征。例如，神经元分量 $\mathcal{O} = z_i^{(\ell)}(x)$ 描述在输入 x 上求值的第 ℓ 层特征；而在神经元指标 $i \neq j$ 时， $\mathcal{O} = z_i^{(\ell)}(x) z_j^{(\ell)}(x)$ 追踪给定 x 时不同特征之间的相关性。

采用与此前类似的操作，只依赖第 ℓ 层预激活的可观测量 $\mathcal{O}$ ，

$$\mathcal{O}(\theta) \equiv \mathcal{O}\left(z^{(\ell)}(x_{\delta_1}; \theta), \dots, z^{(\ell)}(x_{\delta_M}; \theta)\right), \quad (8.2)$$

在一次梯度下降更新后按下式演化：

$$\mathcal{O}(\theta(t+1)) - \mathcal{O}(\theta(t)) = -\eta \sum_{i_1, i_2=1}^{n_\ell} \sum_{\alpha \in \mathcal{A}} \sum_{\delta \in \mathcal{D}} \left[\frac{d\mathcal{L}_{\mathcal{A}}}{dz_{i_1; \alpha}^{(\ell)}} \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell)}} \right] H_{i_1 i_2; \alpha \delta}^{(\ell)} + O(\eta^2), \quad (8.3)$$

其中，对某个数据集 $\mathcal{D}$ ，有 $x_{\delta_1}, \dots, x_{\delta_M} \in \mathcal{D}$ 。¹³³ 这里定义第 ℓ 层 NTK 为

$$H_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)} \equiv \sum_{\mu, \nu} \lambda_{\mu\nu} \frac{dz_{i_1; \alpha_1}^{(\ell)}}{d\theta_\mu} \frac{dz_{i_2; \alpha_2}^{(\ell)}}{d\theta_\nu}, \quad (8.5)$$

它控制第 ℓ 层观测量的演化；用这一记号，输出 NTK 就是 $H_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell=L)}$ 。注意，每当以上述方式书写第 ℓ 层 NTK 时，我们总是假设学习率张量 $\lambda_{\mu\nu}$ 不混合不同层的网络参数，尽管它一般仍可混合同一层内的偏置与权重。稍后还会进一步限制它。

初始化时，模型参数从其初始化分布中采样，第 ℓ 层 NTK 因而是随机对象。为强调这种随机性，下文将给初始化时的 NTK 加帽： $\hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)}$ 。我们的目标是计算它的统计量。

继续之前，先为学习率张量 $\lambda_{\mu\nu}$ 作一个专门选择会很方便。实践中通常取 $\lambda_{\mu\nu} = \delta_{\mu\nu}$ ，整个模型只有一个全局学习率 η 。即使在更一般的设置中，从同一分布采样的每一组参数也常共享一个学习率。回顾给定层中的偏置共享方差为 $C_b^{(\ell)}$ 的同一分布 (2.19)，权重

¹³³ 不过请注意，这并不像上一章给出的网络输出演化表达式 (7.19) 那么简单。特别地，损失关于第 ℓ 层预激活的导数需要用链式法则计算：

$$\frac{d\mathcal{L}_{\mathcal{A}}}{dz_{i_1; \alpha}^{(\ell)}} = \sum_{j=1}^{n_L} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{j; \alpha}^{(L)}} \frac{dz_{j; \alpha}^{(L)}}{dz_{i_1; \alpha}^{(\ell)}}, \quad (8.4)$$

此时，误差因子 $\partial \mathcal{L}_{\mathcal{A}} / \partial z_{j; \alpha}^{(L)}$ 还要乘以链式法则因子 $dz_{j; \alpha}^{(L)} / dz_{i_1; \alpha}^{(\ell)}$ 。对依赖多个层的预激活的可观测量，(8.3) 的推广还涉及额外的链式法则因子，并要对来自不同层的 NTK 求和。

则类似地共享重缩放权重方差为 $C_W^{(\ell)}$ 的分布 (2.20), 这提示了一个关于**训练超参数**的拟设: 应把学习率张量 $\lambda_{\mu\nu}$ 分解为对角矩阵

$$\lambda_{b_{i_1}^{(\ell)} b_{i_2}^{(\ell)}} = \delta_{i_1 i_2} \lambda_b^{(\ell)}, \quad \lambda_{W_{i_1 j_1}^{(\ell)} W_{i_2 j_2}^{(\ell)}} = \delta_{i_1 i_2} \delta_{j_1 j_2} \frac{\lambda_W^{(\ell)}}{n_{\ell-1}}, \quad (8.6)$$

使同一层的一组偏置具有相同学习率, 同一层的一组权重也具有相同学习率, 并允许这些学习率随层而变.

重要的是, 我们用前一层的宽度 $n_{\ell-1}$ 对给定权重 $W_{i_1 j_1}^{(\ell)}$ 的学习率作了归一化, 正如处理该权重的初始化分布方差时所做的那样. 这一归一化的理由大体相同: 若要得到合理的大宽度展开, 就必须能够独立于偏置学习率调节权重学习率. 此后, 训练超参数将包括全局学习率 η , 以及偏置和权重各自的第 ℓ 层学习率 $\lambda_b^{(\ell)}$ 与 $\lambda_W^{(\ell)}$.

把对 $\lambda_{\mu\nu}$ 的选择代回第 ℓ 层 NTK 的定义 (8.5), 该表达式分解为

$$\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)} = \sum_{\ell'=1}^{\ell} \left[\sum_{j=1}^{n_{\ell'}} \left(\lambda_b^{(\ell')} \frac{dz_{i_1; \alpha_1}^{(\ell)}}{db_j^{(\ell')}} \frac{dz_{i_2; \alpha_2}^{(\ell)}}{db_j^{(\ell')}} + \frac{\lambda_W^{(\ell')}}{n_{\ell'-1}} \sum_{k=1}^{n_{\ell'-1}} \frac{dz_{i_1; \alpha_1}^{(\ell)}}{dW_{jk}^{(\ell')}} \frac{dz_{i_2; \alpha_2}^{(\ell)}}{dW_{jk}^{(\ell')}} \right) \right]. \quad (8.7)$$

方括号中的部分是模型参数对第 ℓ 层 NTK 的逐层贡献, 其中偏置和权重分别处理. 还可以看出, (8.6) 之前的直觉是正确的: 与第一项相比, 第二项还要对第 $(\ell'-1)$ 层神经元指标求和, 因此第 ℓ' 层权重学习率 $\lambda_W^{(\ell')}$ 必须伴随因子 $1/n_{\ell'-1}$. 即便如此, (8.7) 中的层求和仍使表达式略显笨重, 提示我们应寻找另一种表示.

仿照对预激活的分析, 尝试寻找递归表达式. 为此, 考虑第 $(\ell+1)$ 层 NTK, 即 $\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)}$, 并在其定义中把第 $(\ell+1)$ 层项与其余各层分开:

$$\begin{aligned} \widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)} &= \sum_{j=1}^{n_{\ell+1}} \left(\lambda_b^{(\ell+1)} \frac{dz_{i_1; \alpha_1}^{(\ell+1)}}{db_j^{(\ell+1)}} \frac{dz_{i_2; \alpha_2}^{(\ell+1)}}{db_j^{(\ell+1)}} + \frac{\lambda_W^{(\ell+1)}}{n_{\ell}} \sum_{k=1}^{n_{\ell}} \frac{dz_{i_1; \alpha_1}^{(\ell+1)}}{dW_{jk}^{(\ell+1)}} \frac{dz_{i_2; \alpha_2}^{(\ell+1)}}{dW_{jk}^{(\ell+1)}} \right) \\ &\quad + \sum_{j_1, j_2=1}^{n_{\ell}} \frac{dz_{i_1; \alpha_1}^{(\ell+1)}}{dz_{j_1; \alpha_1}^{(\ell)}} \frac{dz_{i_2; \alpha_2}^{(\ell+1)}}{dz_{j_2; \alpha_2}^{(\ell)}} \widehat{H}_{j_1 j_2; \alpha_1 \alpha_2}^{(\ell)}. \end{aligned} \quad (8.8)$$

第一行是单独保留的第 $(\ell+1)$ 层项; 第二行则是在其余各层项中应用链式法则, 再利用定义 (8.7) 得到的. 于是第 ℓ 层 NTK 自然出现. 这意味着, 可以找到一个简单的 NTK 迭代表达式, 其思想与定义 MLP 的预激活前向方程相似.

为完成推导, 需要计算 (8.8) 中的导数. 回顾预激活的前向迭代方程

$$z_{i; \alpha}^{(\ell+1)} = b_i^{(\ell+1)} + \sum_{j=1}^{n_{\ell}} W_{ij}^{(\ell+1)} \sigma_{j; \alpha}^{(\ell)}, \quad (8.9)$$

并记住激活是预激活的显式函数, $\sigma_{i; \alpha}^{(\ell)} \equiv \sigma(z_{i; \alpha}^{(\ell)})$. (8.8) 第二行中来自链式法则的因子为

$$\frac{dz_{i; \alpha}^{(\ell+1)}}{dz_{j; \alpha}^{(\ell)}} = W_{ij}^{(\ell+1)} \sigma'_{j; \alpha}^{(\ell)}, \quad (8.10)$$

而关于第 $(\ell+1)$ 层参数的导数为

$$\frac{dz_{i; \alpha}^{(\ell+1)}}{db_j^{(\ell+1)}} = \delta_{ij}, \quad \frac{dz_{i; \alpha}^{(\ell+1)}}{dW_{jk}^{(\ell+1)}} = \delta_{ij} \sigma_{k; \alpha}^{(\ell)}. \quad (8.11)$$

合在一起, 可将 (8.8) 改写为

$$\begin{aligned} \hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)} = & \delta_{i_1 i_2} \left[\lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)} \right) \right] \\ & + \sum_{j_1, j_2=1}^{n_\ell} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \sigma_{j_1; \alpha_1}'^{(\ell)} \sigma_{j_2; \alpha_2}'^{(\ell)} \hat{H}_{j_1 j_2; \alpha_1 \alpha_2}^{(\ell)}. \end{aligned} \quad (8.12)$$

这就是 **NTK 的前向方程**: 对偏置与权重的任一实例, 它逐层迭代计算 NTK. 这与 (8.9) 通过给定模型参数实例的逐层迭代, 计算网络输出以及全部隐藏层预激活的方式类似.

有效理论中的缩放

前向方程 (8.12) 进一步阐明了 (8.6) 中的分解: 我们区分偏置与权重的学习率, 并让二者相对于网络层宽 n_ℓ 具有不同缩放.¹³⁴

为说明原因, 先回顾 §7: 一次梯度下降后训练损失的变化, 正比于全局学习率 η 与末层 NTK $\hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(L)}$ 的乘积:

$$\Delta \mathcal{L}_{\mathcal{A}} = -\eta \sum_{i_1, i_2=1}^{n_L} \sum_{\alpha_1, \alpha_2 \in \mathcal{A}} \epsilon_{i_1; \alpha_1} \epsilon_{i_2; \alpha_2} \hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(L)} + O(\eta^2), \quad (8.13)$$

这里同时回顾误差因子的定义

$$\epsilon_{i; \alpha} \equiv \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i; \alpha}^{(L)}}. \quad (8.14)$$

注意, 在大宽度极限中, 该误差因子一般保持为一阶量; 可与使用 MSE 损失时的显式表达式 (7.15) 比较. 因此, 对大宽度网络而言, 全局学习率与 NTK 的乘积 $\eta \hat{H}^{(L)}$ 也必须保持为一阶量: 若它随宽度发散, (8.13) 中的高阶项就会占主导, 损失将不再保证下降; 若它在此极限中消失, 则不会发生训练. 无论哪种情形, 训练都会失败.

有鉴于此, 我们选择学习率张量的宽度缩放, 使 NTK 在大宽度极限中自然保持一阶, 从而一个足够小却不参数化地小的一阶全局学习率 η 能保证训练成功. 具体而言, 若取 $\lambda_b^{(\ell+1)}, \lambda_W^{(\ell+1)} = O(1)$, 则前向方程 (8.12) 第一行中第 $(\ell+1)$ 层的贡献保持一阶; 其中, 第 $(\ell+1)$ 层权重学习率的 $1/n_\ell$ 归一化, 在补偿对 n_ℓ 项求和时至关重要.¹³⁵

反之, 如果考虑的不是张量梯度下降, 而是取 $\lambda_{\mu\nu} = \delta_{\mu\nu}$ 的原始梯度下降, 就会遇到麻烦. 用有效理论的语言, 原始梯度下降对应于令 $\lambda_b^{(\ell)} = 1, \lambda_W^{(\ell)} = n_{\ell-1}$, 这意味着 NTK

¹³⁴ 要到 §9 才会明白, 为何让 $\lambda_b^{(\ell)}$ 和 $\lambda_W^{(\ell)}$ 依赖层数是有利的, 以及它们应如何随深度缩放.

¹³⁵ 采用这一选择, 前向方程 (8.12) 第二行中的递归项也保持一阶. 为此计算其期望:

$$\begin{aligned} \mathbb{E} \left[\sum_{j_1, j_2=1}^{n_\ell} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \sigma_{j_1; \alpha_1}'^{(\ell)} \sigma_{j_2; \alpha_2}'^{(\ell)} \hat{H}_{j_1 j_2; \alpha_1 \alpha_2}^{(\ell)} \right] &= \sum_{j_1, j_2=1}^{n_\ell} \mathbb{E} \left[W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \right] \mathbb{E} \left[\sigma_{j_1; \alpha_1}'^{(\ell)} \sigma_{j_2; \alpha_2}'^{(\ell)} \hat{H}_{j_1 j_2; \alpha_1 \alpha_2}^{(\ell)} \right] \\ &= \delta_{i_1 i_2} C_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_1}'^{(\ell)} \sigma_{j; \alpha_2}'^{(\ell)} \hat{H}_{jj; \alpha_1 \alpha_2}^{(\ell)} \right] \right). \end{aligned} \quad (8.15)$$

特别地可以看出, 初始化权重方差 $C_W^{(\ell+1)}$ 的 $1/n_\ell$ 缩放, 不仅对保证网络输出的有原则行为重要, 对 NTK 也同样重要.

本身为 $O(n)$. 为补偿 NTK 的这一 $O(n)$ 缩放, 就必须令全局学习率按 $\eta = O(1/n)$ 缩放. 然而, 此时 $\eta\lambda_b^{(\ell)} = O(1/n)$, 权重对 NTK 的一阶贡献将完全压倒偏置受 $1/n$ 抑制的贡献. 这既会使偏置对权重更新缺少适当贡献, 也会使偏置本身受到极端不足的训练.

最后作一个一般性说明: 在任何有效理论中, 都必须把所有大尺度或小尺度显式写出, 并相应重缩放超参数——此前对权重初始化分布方差如此, 这里对权重学习率如此, 稍后对偏置和权重学习率的深度缩放也将如此. 对有效理论研究者而言, 这保证渐近 $1/n$ 与 $1/\ell$ 展开合理且非平凡; 对实践者而言, 这使不同宽度与深度架构之间的超数值可以比较. 特别地, 我们一般预期, 这将有助于缓解代价高昂的超参数调优, 消除启发式修补的需要, 并在扩大模型规模时提高最优超参数设置的稳健性.

把事情弄反了

注意, 计算网络输出关于模型参数的导数时, 也会出现链式法则因子 (8.10):

$$\frac{dz_{i;\alpha}^{(L)}}{db_j^{(\ell)}} = \frac{dz_{i;\alpha}^{(L)}}{dz_{j;\alpha}^{(\ell)}}, \quad \frac{dz_{i;\alpha}^{(L)}}{dW_{jk}^{(\ell)}} = \sum_m \frac{dz_{i;\alpha}^{(L)}}{dz_{m;\alpha}^{(\ell)}} \frac{dz_{m;\alpha}^{(\ell)}}{dW_{jk}^{(\ell)}} = \frac{dz_{i;\alpha}^{(L)}}{dz_{j;\alpha}^{(\ell)}} \sigma_{k;\alpha}^{(\ell-1)}. \quad (8.16)$$

计算这些导数会得到另一个神经网络迭代方程:

$$\frac{dz_{i;\alpha}^{(L)}}{dz_{j;\alpha}^{(\ell)}} = \sum_{k=1}^{n_{\ell+1}} \frac{dz_{i;\alpha}^{(L)}}{dz_{k;\alpha}^{(\ell+1)}} \frac{dz_{k;\alpha}^{(\ell+1)}}{dz_{j;\alpha}^{(\ell)}} = \sum_{k=1}^{n_{\ell+1}} \frac{dz_{i;\alpha}^{(L)}}{dz_{k;\alpha}^{(\ell+1)}} W_{kj}^{(\ell+1)} \sigma_{j;\alpha}^{(\ell)} \quad \text{for } \ell < L, \quad (8.17)$$

不过这里迭代的是输出的导数. 特别地, (8.17) 是一个反向方程: 从终端条件

$$\frac{dz_{i;\alpha}^{(L)}}{dz_{j;\alpha}^{(L)}} = \delta_{ij}, \quad (8.18)$$

出发, 通过依次乘以链式法则因子 (8.10), 按 $\ell = L-1, L-2, \dots, 1$ 逐层向后迭代.

基于这一反向方程的算法可以高效计算关于模型参数的导数, 因此大多数深度学习软件包都用在任意神经网络的基于梯度学习算法中计算梯度. 这类软件包通常让实践者通过定义**前向传播**来指定深度学习模型——对 MLP, 实践者会实现前向方程 (8.9)——随后软件包自动求出**反向传播**——即对 MLP 实现 (8.17). 基于 (8.17) 的计算算法称为**误差反向传播**; 在深度学习史上, 它曾多次被发现和重新发现. 其中一次特别重要的重新发现 [15], 使机器学习共同体相信多层神经网络可以得到高效训练.

尽管如此, 在有效理论中计算 NTK 时, 关键是使用前向方程 (8.12), 而不是把事情弄反. 在接下来的三个加一个小节中, 我们确实会用前向方程, 递归计算第 ℓ 层预激活与第 ℓ 层 NTK 的联合初始化分布:

$$p\left(z^{(\ell)}, \hat{H}^{(\ell)} \middle| \mathcal{D}\right) \equiv p \left(\begin{pmatrix} z^{(\ell)}(x_1) & z^{(\ell)}(x_2) & \dots & z^{(\ell)}(x_{N_{\mathcal{D}}}) \\ \hat{H}^{(\ell)}(x_1, x_1) & \hat{H}^{(\ell)}(x_1, x_2) & \dots & \hat{H}^{(\ell)}(x_1, x_{N_{\mathcal{D}}}) \\ \hat{H}^{(\ell)}(x_2, x_1) & \hat{H}^{(\ell)}(x_2, x_2) & \dots & \hat{H}^{(\ell)}(x_2, x_{N_{\mathcal{D}}}) \\ \vdots & \vdots & \ddots & \vdots \\ \hat{H}^{(\ell)}(x_{N_{\mathcal{D}}}, x_1) & \hat{H}^{(\ell)}(x_{N_{\mathcal{D}}}, x_2) & \dots & \hat{H}^{(\ell)}(x_{N_{\mathcal{D}}}, x_{N_{\mathcal{D}}}) \end{pmatrix} \right). \quad (8.19)$$

(右侧省略了神经元指标，同时显式写出输入依赖。这强调预激活各自是单个输入的函数，而 NTK 分量各自是输入对的函数。)

8.1 第一层：确定性 NTK

回顾 §4.1，初始化时第一层预激活

$$z_{i;\alpha}^{(1)} \equiv b_i^{(1)} + \sum_{j=1}^{n_0} W_{ij}^{(1)} x_{j;\alpha}, \quad (8.20)$$

服从零均值高斯分布

$$p(z^{(1)} | \mathcal{D}) = \frac{1}{|2\pi G^{(1)}|^{\frac{n_1}{2}}} \exp\left(-\frac{1}{2} \sum_{i=1}^{n_1} \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} G_{(1)}^{\alpha_1 \alpha_2} z_{i;\alpha_1}^{(1)} z_{i;\alpha_2}^{(1)}\right), \quad (8.21)$$

其中第一层的确定性度量——输入的函数——为

$$G_{\alpha_1 \alpha_2}^{(1)} \equiv C_b^{(1)} + C_W^{(1)} \frac{1}{n_0} \sum_{j=1}^{n_0} x_{j;\alpha_1} x_{j;\alpha_2}. \quad (8.22)$$

特别地，(8.21) 指数中的二次作用量表明神经元之间不存在相互作用。因而，第一层可观测量的期望值可以分解成每个神经元各自独立的高斯积分。

初始化时第一层 NTK 更加简单：在 NTK 的原始定义 (8.7) 中代入导数 (8.11)，并记住恒等关系 $\sigma_{i;\alpha}^{(0)} = x_{i;\alpha}$ ，便可直接读出

$$\hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(1)} = \delta_{i_1 i_2} \left[\lambda_b^{(1)} + \lambda_W^{(1)} \left(\frac{1}{n_0} \sum_{j=1}^{n_0} x_{j;\alpha_1} x_{j;\alpha_2} \right) \right] \equiv \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(1)}. \quad (8.23)$$

与第一层度量一样，第一层 NTK 完全确定——所以等式右端没有帽——并且在神经元指标上为对角形式。回顾 §7.2 中关于 NTK 非对角分量的说明，这尤其意味着：对单层网络，某个神经元所捕获的特征不能影响另一神经元上另一特征的梯度下降更新。

最后，回顾 §2.3 中关于确定性分布的讨论，第一层预激活与第一层 NTK 的联合分布可写为

$$p(z^{(1)}, \hat{H}^{(1)} | \mathcal{D}) = p(z^{(1)} | \mathcal{D}) \prod_{(i_1 i_2), (\alpha_1 \alpha_2)} \delta\left(\hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(1)} - \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(1)}\right), \quad (8.24)$$

其中 Dirac delta 函数之积遍历所有神经元指标对与样本指标对。正如第一层预激活分布代表无限宽极限中的更深层一样，该第一层联合分布也代表无限宽极限中的更深层联合分布：预激活分布严格为高斯，NTK 分布完全确定，并且二者不相关；也就是说，固定数据集后，它们彼此统计独立。

8.2 第二层：涨落的 NTK

现在来看有限宽修正如何在第二层改变上述图景.

回顾 §4.2, 第二层预激活为

$$z_{i;\alpha}^{(2)} = b_i^{(2)} + \sum_{j=1}^{n_1} W_{ij}^{(2)} \sigma_{j;\alpha}^{(1)}. \quad (8.25)$$

把第一层预激活 $z^{(1)}$ 边缘化后, 第一层预激活的相关涨落在第二层不同神经元之间产生非平凡相互作用. 在 $1/n_1$ 的首个非平凡阶, 这给出具有四次作用量 (4.60) 的第二层预激活近高斯分布; 其领先非高斯性由非零连通四点相关函数刻画.

对 NTK 而言, 考察其前向方程 (8.12), 并回顾第一层 NTK 是确定的 (8.23), 可见第二层 NTK 为

$$\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} = \delta_{i_1 i_2} \left[\lambda_b^{(2)} + \lambda_W^{(2)} \left(\frac{1}{n_1} \sum_{j=1}^{n_1} \sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \right) \right] + \sum_{j=1}^{n_1} W_{i_1 j}^{(2)} W_{i_2 j}^{(2)} \sigma'_{j;\alpha_1}{}^{(1)} \sigma'_{j;\alpha_2}{}^{(1)} H_{\alpha_1 \alpha_2}^{(1)}. \quad (8.26)$$

该第二层 NTK 依赖两组随机变量, 即权重 $W_{ij}^{(2)}$ 与第一层预激活 $z_{i;\alpha}^{(1)}$, 因此会发生涨落.

为计算其均值, 对 (8.26) 取期望, 得到

$$\begin{aligned} & \mathbb{E} \left[\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \right] \\ &= \delta_{i_1 i_2} \left[\lambda_b^{(2)} + \lambda_W^{(2)} \left(\frac{1}{n_1} \sum_{j=1}^{n_1} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(1)} \sigma_{j;\alpha_2}^{(1)} \right] \right) \right] + \sum_{j=1}^{n_1} \mathbb{E} \left[W_{i_1 j}^{(2)} W_{i_2 j}^{(2)} \right] \mathbb{E} \left[\sigma'_{j;\alpha_1}{}^{(1)} \sigma'_{j;\alpha_2}{}^{(1)} \right] H_{\alpha_1 \alpha_2}^{(1)} \\ &= \delta_{i_1 i_2} \left[\lambda_b^{(2)} + \lambda_W^{(2)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} + C_W^{(2)} \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(1)}} H_{\alpha_1 \alpha_2}^{(1)} \right] \\ &\equiv \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(2)}. \end{aligned} \quad (8.27)$$

第二行中递归项的期望能够因式分解, 是因为第二层权重 $W_{ij}^{(2)}$ 与第一层预激活统计独立. 第三行还回顾了 (4.27): 其中证明二点相关函数可表示为各神经元分别进行的高斯期望, 方差由第一层度量 $G^{(1)}$ 给出.¹³⁶ 进一步检查结果 (8.27) 可见, 第二层 NTK 的均值在神经元指标上为对角形式. 此外, 我们把编码样本依赖的部分分离出来, 并去掉其帽号, 因为它是均值而非随机变量.

现在计算方差. 首先用通常的分解定义第二层 NTK 涨落:

$$\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \equiv \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(2)} + \widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)}, \quad (8.28)$$

于是该涨落幅度的期望决定协方差:

$$\mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] = \mathbb{E} \left[\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] - \mathbb{E} \left[\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \right] \mathbb{E} \left[\widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right]. \quad (8.29)$$

¹³⁶ 注意, 无论高斯期望的对象是激活还是激活的导数, (4.27) 附近的逻辑都相同. 换言之, 对第一层预激活也有 $\mathbb{E} \left[\sigma'_{j;\alpha_1}{}^{(1)} \sigma'_{j;\alpha_2}{}^{(1)} \right] = \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(1)}}$.

代入第二层随机 NTK 的表达式 (8.26)，并利用第二层权重与第一层预激活的独立性，得到一个看似复杂的结果：

$$\begin{aligned}
& \mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] \\
&= \frac{1}{n_1} \delta_{i_1 i_2} \delta_{i_3 i_4} \left\{ \left(\lambda_W^{(2)} \right)^2 \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \right] \right. \\
&\quad + C_W^{(2)} H_{\alpha_1 \alpha_2}^{(1)} \lambda_W^{(2)} \left[\langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \right] \\
&\quad + \lambda_W^{(2)} C_W^{(2)} H_{\alpha_3 \alpha_4}^{(1)} \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} \right] \\
&\quad \left. + \left(C_W^{(2)} \right)^2 H_{\alpha_1 \alpha_2}^{(1)} H_{\alpha_3 \alpha_4}^{(1)} \left[\langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} \right] \right\} \\
&\quad + \frac{1}{n_1} (\delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \left(C_W^{(2)} \right)^2 H_{\alpha_1 \alpha_2}^{(1)} H_{\alpha_3 \alpha_4}^{(1)} \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}}.
\end{aligned} \tag{8.30}$$

为得到该表达式，除二点相关函数的 (4.27) 外，还回顾了四点相关函数不同配对所需的 (4.28) 与 (4.29)；配对分别取决于所有激活位于同一神经元，还是位于两个不同神经元。与上面的均值计算一样，无论激活是否带导数，这些四点相关函数的计算方式都类似。

为理解这个相当不美观的表达式 (8.30)，先把第二层 NTK 方差分解为两类张量之和：

$$\begin{aligned}
& \mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(2)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] \\
&\equiv \frac{1}{n_1} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(2)} + \delta_{i_1 i_3} \delta_{i_2 i_4} B_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)} + \delta_{i_1 i_4} \delta_{i_2 i_3} B_{\alpha_1 \alpha_4 \alpha_2 \alpha_3}^{(2)} \right].
\end{aligned} \tag{8.31}$$

这一分解由 (8.30) 中出现的 Kronecker delta 型式启发。将它与原表达式 (8.30) 比较，可见这些张量为

$$A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(2)} = \left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(2)} \widehat{\Omega}_{\alpha_3 \alpha_4}^{(2)} \right\rangle_{G^{(1)}} - \left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(2)} \right\rangle_{G^{(1)}} \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(2)} \right\rangle_{G^{(1)}}, \tag{8.32}$$

$$B_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)} = \left(C_W^{(2)} \right)^2 H_{\alpha_1 \alpha_2}^{(1)} H_{\alpha_3 \alpha_4}^{(1)} \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}}, \tag{8.33}$$

其中第一行引入了辅助随机变量

$$\widehat{\Omega}_{\alpha_1 \alpha_2}^{(2)} \equiv \lambda_W^{(2)} \sigma_{\alpha_1}^{(1)} \sigma_{\alpha_2}^{(1)} + C_W^{(2)} H_{\alpha_1 \alpha_2}^{(1)} \sigma_{\alpha_1}^{\prime(1)} \sigma_{\alpha_2}^{\prime(1)}, \tag{8.34}$$

以改善原本会十分冗长的表达式。¹³⁷ 由 (8.32) 与 (8.33) 可清楚看出，这些张量都是一阶量。再结合 (8.31)，这意味着第二层 NTK 方差在大宽度极限中受 $1/n_1$ 抑制。换言之

¹³⁷ 注意， $A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(2)}$ (8.32) 与四点顶角 $V_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell)}$ 具有相同对称性。特别地，它在交换样本指标 $\alpha_1 \leftrightarrow \alpha_2$ 、 $\alpha_3 \leftrightarrow \alpha_4$ 以及 $(\alpha_1 \alpha_2) \leftrightarrow (\alpha_3 \alpha_4)$ 下对称，而且该对称性延续到更深层，参见 (8.97)。

你或许会举手说， $B_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)}$ (8.33) 也具有同一对称性。在这里确实如此，但该对称性会在更深层破缺。一般地——参见 (8.89)—— $B_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(\ell)}$ 在 $(\alpha_1 \alpha_2) \leftrightarrow (\alpha_3 \alpha_4)$ 与 $(\alpha_1 \alpha_3) \leftrightarrow (\alpha_2 \alpha_4)$ 下对称，却不分别在 $\alpha_1 \leftrightarrow \alpha_2$ 或 $\alpha_3 \leftrightarrow \alpha_4$ 下对称。

之，第二层 NTK 在严格无限宽极限中是确定的；离开该极限后，它则按 (8.31)、(8.32) 与 (8.33) 发生涨落。

此外，在有限宽度下，第二层 NTK 不仅会涨落，还与第二层预激活具有非平凡的交叉相关。这最终可追溯到第二层预激活 (8.25) 与第二层 NTK (8.26) 都是同一组随机变量的函数：第二层权重 $W_{ij}^{(2)}$ 和第一层预激活 $z_{i;\alpha}^{(1)}$ 。

该交叉相关可用与计算 NTK 均值和方差类似的方法求出。代入第二层预激活的定义 (8.25) 与第二层 NTK (8.26)，并再次利用第二层权重 $W_{ij}^{(2)}$ 与第一层预激活 $z_{i;\alpha}^{(1)}$ 的统计独立性，得到

$$\mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} \widehat{\Delta H}_{i_2 i_3; \alpha_2 \alpha_3}^{(2)} \right] = 0, \quad (8.35)$$

$$\begin{aligned} \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] &= \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} \widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] - \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} \right] \mathbb{E} \left[\widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] \\ &= \frac{1}{n_1} \delta_{i_1 i_2} \delta_{i_3 i_4} \left\{ \lambda_W^{(2)} C_W^{(2)} \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma_{\alpha_3} \sigma_{\alpha_4} \rangle_{G^{(1)}} \right] \right. \\ &\quad \left. + \left(C_W^{(2)} \right)^2 H_{\alpha_3 \alpha_4}^{(1)} \left[\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}} \right] \right\} \\ &\quad + \frac{1}{n_1} (\delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) \left(C_W^{(2)} \right)^2 H_{\alpha_3 \alpha_4}^{(1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}}. \end{aligned} \quad (8.36)$$

这里与方差 (8.30) 的情形一样，使用了适当推广的 (4.27)、(4.28) 与 (4.29) 来处理二点和四点相关函数。因此可见，第二层预激活与第二层 NTK 之间的第一种交叉相关度量 (8.35) 消失，而第二种 (8.36) 在有限宽度下非零。

为便于深层分析，仿照 (8.31) 中对方差的处理，把交叉相关 (8.36) 分解成两个只带样本指标的张量：

$$\begin{aligned} \mathbb{E} \left[z_{i_1;\alpha_1}^{(2)} z_{i_2;\alpha_2}^{(2)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(2)} \right] \\ = \frac{1}{n_1} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(2)} + \delta_{i_1 i_3} \delta_{i_2 i_4} F_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)} + \delta_{i_1 i_4} \delta_{i_2 i_3} F_{\alpha_1 \alpha_4 \alpha_2 \alpha_3}^{(2)} \right]. \end{aligned} \quad (8.37)$$

将该分解与相关函数的显式公式 (8.36) 比较，可辨认出

$$D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(2)} = C_W^{(2)} \left[\left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \widehat{\Omega}_{\alpha_3 \alpha_4}^{(2)} \right\rangle_{G^{(1)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(1)}} \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(2)} \right\rangle_{G^{(1)}} \right], \quad (8.38)$$

$$F_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)} = \left(C_W^{(2)} \right)^2 H_{\alpha_3 \alpha_4}^{(1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(1)}}, \quad (8.39)$$

这里还回顾了 (8.34) 中定义的随机张量 $\widehat{\Omega}_{\alpha_1 \alpha_2}^{(2)}$ 。¹³⁸ 正如上面的 $A^{(2)}$ 与 $B^{(2)}$ ， $D^{(2)}$ 与 $F^{(2)}$ 也显然都是一阶量。与第二层 NTK 方差类似，这意味着交叉相关函数 (8.37) 在大宽度极限中受 $1/n_1$ 抑制，并在严格无限宽极限中消失。

总之，在 $1/n$ 展开的首个非平凡阶，第二层预激活与第二层 NTK 的联合分布

$$p \left(z^{(2)}, \widehat{H}^{(2)} \middle| \mathcal{D} \right), \quad (8.40)$$

¹³⁸ 交叉相关张量 $D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(2)}$ (8.38)——以及更深层中一般的 $D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(\ell)}$ ，参见 (8.77)——在交换样本指标 $\alpha_1 \leftrightarrow \alpha_2$ 与 $\alpha_3 \leftrightarrow \alpha_4$ 下对称，但当然不在 $(\alpha_1 \alpha_2) \leftrightarrow (\alpha_3 \alpha_4)$ 下对称。另一个张量 $F_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(2)}$ (8.39) 在第二层具有同一对称性，但在更深层完全没有对称性，参见 (8.79)。

是一个近高斯分布，具有：(i) 不同神经元的预激活之间的四次相互作用，(ii) 涨落的 NTK，以及 (iii) 预激活与 NTK 之间的交叉相关。在更深层，所有这些有限宽效应都会变得更加复杂。

8.3 更深层：NTK 涨落的累积

正如 §4.1 || §8.1 与 §4.2 || §8.2 的对应关系，本节对应于 §4.3。在 §4.3 中，我们通过考虑层间联合分布 $p(z^{(\ell+1)}, z^{(\ell)} | \mathcal{D})$ ，再积掉第 ℓ 层预激活，研究了有限宽度下预激活的近高斯分布 $p(z^{(\ell+1)} | \mathcal{D})$ 。特别地，由于对前面各层预激活的相关依赖，预激活分布中的非高斯性随深度增加而累积，并表现为流动的四点顶角 $V^{(\ell)}$ 。

同一机制也使 NTK 涨落累积，既放大 NTK 方差，也放大 NTK 与预激活之间的交叉相关。本节将推导 NTK 均值、NTK-预激活交叉相关及 NTK 方差的递推关系；它们共同决定 $1/n$ 首个非平凡阶的第 ℓ 层联合分布。接下来是一段古典老派计算，所以请削尖羽毛笔、铺开羊皮纸，并通知管家为你清空今天余下的日程。

8.3.0 层间插曲：层间相关

如果你有过目不忘的记忆，也许还记得，与第二层统计相比，推导一般第 $(\ell+1)$ 层预激活统计的主要复杂之处在于：不同于第一层的高斯预激活分布，第 ℓ 层预激活分布 $p(z^{(\ell)} | \mathcal{D})$ 本身也是非高斯的。对这样的近高斯分布 $p(z^{(\ell)} | \mathcal{D})$ ，相互作用意味着不同神经元 $i_1 \neq i_2$ 上预激活可观测量之间存在非平凡的**层内相关**。具体而言，分别依赖数据子样本 $\mathcal{A}_1, \mathcal{A}_2 \subset \mathcal{D}$ 的两个任意单神经元函数 $\mathcal{F}(z_{i_1; \mathcal{A}_1}^{(\ell)})$ 与 $\mathcal{G}(z_{i_2; \mathcal{A}_2}^{(\ell)})$ 的协方差由 (4.64) 给出，这里重印如下：

$$\begin{aligned} \text{Cov} \left[\mathcal{F}(z_{i_1; \mathcal{A}_1}^{(\ell)}), \mathcal{G}(z_{i_2; \mathcal{A}_2}^{(\ell)}) \right] &\equiv \mathbb{E} \left[\mathcal{F}(z_{i_1; \mathcal{A}_1}^{(\ell)}) \mathcal{G}(z_{i_2; \mathcal{A}_2}^{(\ell)}) \right] - \mathbb{E} \left[\mathcal{F}(z_{i_1; \mathcal{A}_1}^{(\ell)}) \right] \mathbb{E} \left[\mathcal{G}(z_{i_2; \mathcal{A}_2}^{(\ell)}) \right] \\ &= \sum_{\beta_1, \dots, \beta_4 \in \mathcal{D}} \frac{1}{4n_{\ell-1}} V_{(\ell)}^{(\beta_1 \beta_2)(\beta_3 \beta_4)} \left\langle \left(z_{\beta_1} z_{\beta_2} - G_{\beta_1 \beta_2}^{(\ell)} \right) \mathcal{F}(z_{\mathcal{A}_1}) \right\rangle_{G^{(\ell)}} \left\langle \left(z_{\beta_3} z_{\beta_4} - G_{\beta_3 \beta_4}^{(\ell)} \right) \mathcal{G}(z_{\mathcal{A}_2}) \right\rangle_{G^{(\ell)}} \\ &\quad + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (8.41)$$

在这一重印式中，我们已经隐式代入二次耦合 $g_{(\ell)}$ 和四次耦合 $v_{(\ell)}$ 的领先大宽度表达式 (4.81) 与 (4.82)。还回顾了早已被遗忘的随机变量协方差简写 (1.53)；本节将审慎使用它。这个层内公式很快就会证明其用处。

把视野扩大到预激活-NTK 联合分布 (8.19)，还会遇到由如下形式的**层间相关**引起的另一项复杂性：

$$\mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \mathcal{P}(W^{(\ell+1)}) \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}) \right], \quad (8.42)$$

其中， $\mathcal{O}$ 是第 $(\ell+1)$ 层预激活的某个函数， $\mathcal{P}$ 是第 $(\ell+1)$ 层权重的多项式，而 $\mathcal{Q}$ 是第 ℓ 层预激活与第 ℓ 层 NTK 的函数。例如，取 NTK-预激活交叉相关

$$\mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)} \hat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] \quad (8.43)$$

并利用前向方程 (8.12) 展开 NTK，会从方括号中的加性项得到形如 (8.42)、且 $\mathcal{P} = 1$ 的层间相关；从递归项则得到同一形式、且 $\mathcal{P} = W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)}$ 的层间相关。对第二层而言，计算这类期望相当简单，但对一般层则颇为微妙。

不过，确实有一个相当巧妙的办法，可以把这类层间相关 (8.42) 化为只含第 ℓ 层变量的期望。随后便可用上面的层内公式 (8.41) 计算这些期望。在深入更深层分析之前，先教你这个魔术。¹³⁹

第一，利用期望的定义和分布的条件结构，层间相关 (8.42) 可表示为（省略全部指标）

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \mathcal{P}(W^{(\ell+1)}) \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}) \right] \\ &= \int dz^{(\ell)} d\hat{H}^{(\ell)} p(z^{(\ell)}, \hat{H}^{(\ell)} | \mathcal{D}) \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}) \\ & \quad \times \left[\int db^{(\ell+1)} dW^{(\ell+1)} p(b^{(\ell+1)}) p(W^{(\ell+1)}) \mathcal{P}(W^{(\ell+1)}) \right. \\ & \quad \left. \times \int dz^{(\ell+1)} p(z^{(\ell+1)} | b^{(\ell+1)}, W^{(\ell+1)}, z^{(\ell)}) \mathcal{O}(z^{(\ell+1)}) \right]. \end{aligned} \quad (8.44)$$

我们的策略是积掉第 $(\ell + 1)$ 层参数，或对其作边缘化，从而把方括号内的对象表示成仅含第 ℓ 层变量的函数。这样，整个对象就成为我们已经知道如何处理的第 ℓ 层期望。

第二，与其处理抽象多项式 $\mathcal{P}$ ，不如利用源项为这些层间相关构造一个生成函数：

$$\mathcal{P}(W^{(\ell+1)}) = e^{\sum_{i,j} \mathcal{J}_{ij} W_{ij}^{(\ell+1)}}. \quad (8.45)$$

回想预训练时代 (§1.1)，像 (8.45) 这样的生成函数可用来计算带任意权重多项式 $W_{ij}^{(\ell+1)}$ 插入的期望 (8.42)。为此，对求值后的生成函数关于源 $\mathcal{J}_{ij}$ 求若干次导数，再把源设为零。

现在对 $\mathcal{P}$ 采用 (8.45)，可按如下步骤显式计算 (8.44) 方括号中的表达式：(i) 回顾偏置和权重的初始化分布 (2.21) 与 (2.22)；(ii) 回顾 (2.34) 中，条件分布 $p(z^{(\ell+1)} | b^{(\ell+1)}, W^{(\ell+1)}, z^{(\ell)})$ 把 MLP 前向方程 (8.9) 编码为 Dirac delta 函数；最后，(iii) 回顾 Dirac delta 函数的积分表示 (2.32)。合在一起得到积分组

¹³⁹ 由于 §11 中也会出现类似的层间相关，我们保持论述完全一般，而不专门限定于 NTK-预激活交叉相关 (8.43)。

$$\begin{aligned}
& \int \left[\prod_i \frac{db_i}{\sqrt{2\pi C_b^{(\ell+1)}}} \right] \left[\prod_{i,j} \frac{dW_{ij}}{\sqrt{2\pi C_W^{(\ell+1)}/n_\ell}} \right] \\
& \times \left[\prod_{i,\alpha} \frac{d\Lambda_i^\alpha dz_{i;\alpha}^{(\ell+1)}}{2\pi} \right] \mathcal{O}(z^{(\ell+1)}) \\
& \times \exp \left[-\sum_i \frac{b_i^2}{2C_b^{(\ell+1)}} - \sum_{i,j} \frac{n_\ell W_{ij}^2}{2C_W^{(\ell+1)}} \right. \\
& \left. + i \sum_{i,\alpha} \Lambda_i^\alpha \left(z_{i;\alpha}^{(\ell+1)} - b_i - \sum_j W_{ij} x_{j;\alpha} \right) + \sum_{i,j} \mathcal{J}_{ij} W_{ij} \right], \tag{8.46}
\end{aligned}$$

这正是我们最早在 §4.1 中遇到的古老 *Hubbard–Stratonovich* 变换。

接下来，仿照 §4.1 以及高中时的做法，可以分别对偏置和权重配方并积掉它们。与 §4.1 的表述相比，这里唯一实质性的差别，是源项把权重的线性耦合平移为

$$-iW_{ij} \sum_\alpha \Lambda_i^\alpha \sigma_{j;\alpha}^{(\ell)} \rightarrow -iW_{ij} \left(\sum_\alpha \Lambda_i^\alpha \sigma_{j;\alpha}^{(\ell)} + i\mathcal{J}_{ij} \right). \tag{8.47}$$

完成这些高斯积分，得到

$$\begin{aligned}
& \int \left[\prod_{i,\alpha} \frac{d\Lambda_i^\alpha dz_{i;\alpha}^{(\ell+1)}}{2\pi} \right] \mathcal{O}(z^{(\ell+1)}) \exp \left[-\sum_{i,\alpha_1,\alpha_2} \Lambda_i^{\alpha_1} \Lambda_i^{\alpha_2} \left(\frac{C_b^{(\ell+1)}}{2} + \frac{C_W^{(\ell+1)}}{2n_\ell} \sum_j \sigma_{\alpha_1;j}^{(\ell)} \sigma_{\alpha_2;j}^{(\ell)} \right) \right. \\
& \left. + i \sum_{i,\alpha} \Lambda_i^\alpha \left(z_{i;\alpha}^{(\ell+1)} - \frac{C_W^{(\ell+1)}}{n_\ell} \sum_j \mathcal{J}_{ij} \sigma_{j;\alpha}^{(\ell)} \right) + \frac{C_W^{(\ell+1)}}{2n_\ell} \sum_{i,j} \mathcal{J}_{ij}^2 \right]. \tag{8.48}
\end{aligned}$$

正如之前的 *Hubbard–Stratonovich* 化 (4.20)，随机度量 (4.70)

$$\widehat{G}_{\alpha_1\alpha_2}^{(\ell+1)} \equiv C_b^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \tag{8.49}$$

出现在 *Hubbard–Stratonovich* 变量 Λ_i^α 的二次项中；线性项则因预激活减去下式而稍有改变：

$$\widehat{\mathcal{M}}_{i;\alpha} \equiv C_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathcal{J}_{ij} \sigma_{j;\alpha}^{(\ell)} \right). \tag{8.50}$$

对 *Hubbard–Stratonovich* 变量配方并积掉它们，得到

$$\begin{aligned}
& \frac{\exp \left(\frac{C_W^{(\ell+1)}}{2n_\ell} \sum_{i,j} \mathcal{J}_{ij}^2 \right)}{\sqrt{|2\pi \widehat{G}^{(\ell+1)}|^{n_{\ell+1}}}} \int \left[\prod_{i,\alpha} dz_{i;\alpha}^{(\ell+1)} \right] \mathcal{O}(z^{(\ell+1)}) \\
& \times \exp \left[-\frac{1}{2} \sum_i \sum_{\alpha_1,\alpha_2} \widehat{G}_{(\ell+1)}^{\alpha_1\alpha_2} \left(z_{i;\alpha_1}^{(\ell+1)} - \widehat{\mathcal{M}}_{i;\alpha_1} \right) \left(z_{i;\alpha_2}^{(\ell+1)} - \widehat{\mathcal{M}}_{i;\alpha_2} \right) \right]. \tag{8.51}
\end{aligned}$$

暂且忽略积分外的二次源因子 $\mathcal{J}_{ij}^2$ ，这只是对第 $(\ell + 1)$ 层预激活分布作 $\mathcal{O}$ 的高斯期望，其均值为 $\widehat{\mathcal{M}}_{i;\alpha}$ 、方差为 $\widehat{G}_{\alpha_1\alpha_2}^{(\ell+1)}$ 。（务必记住我们的广义相对论约定： $\widehat{G}_{(\ell+1)}^{\alpha_1\alpha_2}$ 是 $\widehat{G}_{\alpha_1\alpha_2}^{(\ell+1)}$ 的逆。）

现在通过平移哑积分变量 $z_{i;\alpha}^{(\ell+1)} \rightarrow z_{i;\alpha}^{(\ell+1)} + \widehat{\mathcal{M}}_{i;\alpha_1}$ 补偿这一均值，便得到用零均值高斯期望记号 (4.45) 写成的紧凑表达式：

$$\exp\left(\frac{C_W^{(\ell+1)}}{2n_\ell} \sum_{i,j} \mathcal{J}_{ij}^2\right) \left\langle\left\langle \mathcal{O}\left(z^{(\ell+1)} + \widehat{\mathcal{M}}\right) \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}}. \quad (8.52)$$

把结果 (8.52) 代回层间相关 (8.42)，再代回均值平移 (8.50)，得到生成函数的简单公式：

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) e^{\sum_{i,j} \mathcal{J}_{ij} W_{ij}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right] \\ &= \exp\left(\frac{C_W^{(\ell+1)}}{2n_\ell} \sum_{i,j} \mathcal{J}_{ij}^2\right) \mathbb{E} \left[\left\langle\left\langle \mathcal{O}\left(z_{i;\alpha}^{(\ell+1)} + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathcal{J}_{ij} \sigma_{j;\alpha}^{(\ell)}\right) \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right]. \end{aligned} \quad (8.53)$$

对第 $(\ell + 1)$ 层预激活 $z_{i;\alpha}^{(\ell+1)}$ 完成高斯期望后——在此后遇到的具体应用中通常都很平凡——(8.53) 中的期望只涉及第 ℓ 层变量。¹⁴⁰ 这正是所需结果。

为说明如何使用生成函数 (8.53)，来看几个显式例子。首先考虑没有权重插入的情形。令源为零， $\mathcal{J}_{ij} = 0$ ，得到

$$\mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right] = \mathbb{E} \left[\left\langle\left\langle \mathcal{O}(z^{(\ell+1)}) \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right]. \quad (8.54)$$

该公式并不平凡，也不是此前已知的：相邻层预激活之间的相关，先通过随机度量计算第 $(\ell + 1)$ 层函数的高斯期望，再对所得第 ℓ 层量取完整期望而得到。

接着考虑两次权重插入。对生成函数 (8.53) 关于源作两次微分 $\frac{d}{d\mathcal{J}_{i_3j_3}} \frac{d}{d\mathcal{J}_{i_4j_4}}$ ，再把源设为零，得到

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_3j_3}^{(\ell+1)} W_{i_4j_4}^{(\ell+1)} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right] \\ &= \delta_{i_3i_4} \delta_{j_3j_4} \frac{C_W^{(\ell+1)}}{n_\ell} \mathbb{E} \left[\left\langle\left\langle \mathcal{O} \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right] \\ & \quad + \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{\beta_3, \beta_4, \gamma_3, \gamma_4} \mathbb{E} \left[\left\langle\left\langle \left(z_{i_3;\beta_3}^{(\ell+1)} z_{i_4;\beta_4}^{(\ell+1)} - \delta_{i_3i_4} \widehat{G}_{\beta_3\beta_4}^{(\ell+1)} \right) \mathcal{O} \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}} \right. \\ & \quad \left. \times \widehat{G}_{(\ell+1)}^{\beta_3\gamma_3} \widehat{G}_{(\ell+1)}^{\beta_4\gamma_4} \sigma_{j_3;\gamma_3}^{(\ell)} \sigma_{j_4;\gamma_4}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}) \right]. \end{aligned} \quad (8.55)$$

这里使用分部积分，把导数换成投影：

$$\left\langle\left\langle \frac{\partial^2 \mathcal{O}}{\partial z_{i_3;\gamma_3}^{(\ell+1)} \partial z_{i_4;\gamma_4}^{(\ell+1)}} \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}} = \sum_{\beta_3, \beta_4} \widehat{G}_{(\ell+1)}^{\beta_3\gamma_3} \widehat{G}_{(\ell+1)}^{\beta_4\gamma_4} \left\langle\left\langle \left(z_{i_3;\beta_3}^{(\ell+1)} z_{i_4;\beta_4}^{(\ell+1)} - \delta_{i_3i_4} \widehat{G}_{\beta_3\beta_4}^{(\ell+1)} \right) \mathcal{O} \right\rangle\right\rangle_{\widehat{G}^{(\ell+1)}}. \quad (8.56)$$

¹⁴⁰ 回顾随机度量 $\widehat{G}^{(\ell+1)}$ (8.49) 只依赖第 ℓ 层预激活。

直观地说，(8.55) 的第一项来自两个权重插入之间形成一次 Wick 缩并；第二项来自两对 Wick 缩并，其中每一对都由一个插入的权重与 $\mathcal{O}$ 中 $z^{(\ell+1)}$ 内隐藏的一个权重组成。

至此，已经回顾层内公式 (8.41)，并推导层间公式 (8.54) 与 (8.55)；我们终于准备好递归分析更深层中 NTK 与预激活的联合统计。层间插曲到此结束。

8.3.1 NTK 均值

对随机 NTK 前向方程 (8.12) 取期望，得到

$$\begin{aligned} \mathbb{E} \left[\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)} \right] = & \delta_{i_1 i_2} \left[\lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)} \right] \right) \right] \\ & + \delta_{i_1 i_2} C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \widehat{H}_{jj; \alpha_1 \alpha_2}^{(\ell)} \right], \end{aligned} \quad (8.57)$$

其中，正如现在已经熟悉的那样，第二行使用了第 $(\ell+1)$ 层权重与第 ℓ 层预激活的独立性，随后立即计算了权重期望。由此立刻可见，在任意网络深度，NTK 均值在神经元指标上都是对角的。

因此，把第 ℓ 层 NTK 分解为均值与涨落：

$$\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)} \equiv \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(\ell)} + \widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)}, \quad (8.58)$$

这里把第 ℓ 层 NTK 均值记作 $\delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(\ell)}$ 。与前面一样，我们从均值中分离出编码样本依赖性的部分，并用不带帽的符号表示它。把这一分解代入 NTK 均值表达式 (8.57)，可见第 $(\ell+1)$ 层均值满足递推关系

$$\begin{aligned} H_{\alpha_1 \alpha_2}^{(\ell+1)} = & \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)} \right] \right) + C_W^{(\ell+1)} H_{\alpha_1 \alpha_2}^{(\ell)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \right] \right) \\ & + C_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \widehat{\Delta H}_{jj; \alpha_1 \alpha_2}^{(\ell)} \right] \right), \end{aligned} \quad (8.59)$$

它同时依赖前一层 ℓ 的均值与涨落。

在 $1/n$ 的领先阶，(8.59) 右端前两个期望值由高斯期望给出：

$$\mathbb{E} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)} \right] = \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right), \quad (8.60)$$

$$\mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \right] = \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right). \quad (8.61)$$

为看清这一点，注意第一个期望正是领先高斯贡献 (4.61)，其中依照 (4.82)，非高斯耦合 v 被压低为 $\sim 1/n$ ；而无论激活是否带导数，第二个期望的计算都与第一个完全相同。与此同时，(8.59) 第二行的最后一个期望涉及 NTK-预激活交叉相关，它在大宽度极限下同样受到压低：

$$\mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \widehat{\Delta H}_{jj; \alpha_1 \alpha_2}^{(\ell)} \right] = O\left(\frac{1}{n}\right). \quad (8.62)$$

我们很快将在下一小节的 (8.71) 中证明这一点.

汇集这些领先贡献, NTK 均值递推关系简化为

$$H_{\alpha_1\alpha_2}^{(\ell+1)} = \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} + C_W^{(\ell+1)} \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(\ell)}} H_{\alpha_1\alpha_2}^{(\ell)} + O\left(\frac{1}{n}\right). \quad (8.63)$$

如果你习惯在书上作标记, 不妨给这个公式画一个方框.

8.3.2 NTK-预激活交叉相关

下面计算一种非常一般的交叉相关期望

$$\mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right]. \quad (8.64)$$

例如, 令 $\mathcal{O} = z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)}$, 便得到基本交叉相关 (8.43); 而令 $\mathcal{O} = \sigma'_{i_1; \alpha_1} \sigma'_{i_2; \alpha_2}$, 则得到刚刚在 NTK 均值递推关系中出现 (随即又消失) 的次领先交叉相关 (8.62).

首先, 把 NTK 前向方程 (8.12) 直接代入交叉相关子 (8.64), 得到

$$\begin{aligned} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] &= \text{Cov} \left[\mathcal{O}(z^{(\ell+1)}), \widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] \\ &= \delta_{i_3 i_4} \lambda_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \left\{ \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \sigma_{j; \alpha_3}^{(\ell)} \sigma_{j; \alpha_4}^{(\ell)} \right] - \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \right] \mathbb{E} \left[\sigma_{j; \alpha_3}^{(\ell)} \sigma_{j; \alpha_4}^{(\ell)} \right] \right\} \\ &\quad + \sum_{j_3, j_4=1}^{n_\ell} \left\{ \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \sigma'_{j_3; \alpha_3}^{(\ell)} \sigma'_{j_4; \alpha_4}^{(\ell)} \widehat{H}_{j_3 j_4; \alpha_3 \alpha_4}^{(\ell)} \right] \right. \\ &\quad \left. - \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \right] \mathbb{E} \left[W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \right] \mathbb{E} \left[\sigma'_{j_3; \alpha_3}^{(\ell)} \sigma'_{j_4; \alpha_4}^{(\ell)} \widehat{H}_{j_3 j_4; \alpha_3 \alpha_4}^{(\ell)} \right] \right\}. \end{aligned} \quad (8.65)$$

现在使用刚刚推导的层间公式 (8.54) 与 (8.55), 该交叉相关子变为

$$\begin{aligned} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] &= \delta_{i_3 i_4} \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} \mathbb{E} \left[\langle \langle \mathcal{O}(z^{(\ell+1)}) \rangle \rangle_{\widehat{G}^{(\ell+1)}} \widehat{\Delta G}_{\alpha_3 \alpha_4}^{(\ell+1)} \right] \\ &\quad + \delta_{i_3 i_4} \frac{C_W^{(\ell+1)}}{n_\ell} \sum_{j=1}^{n_\ell} \left\{ \mathbb{E} \left[\langle \langle \mathcal{O}(z^{(\ell+1)}) \rangle \rangle_{\widehat{G}^{(\ell+1)}} \sigma'_{j; \alpha_3}^{(\ell)} \sigma'_{j; \alpha_4}^{(\ell)} \widehat{H}_{jj; \alpha_3 \alpha_4}^{(\ell)} \right] \right. \\ &\quad \left. - \mathbb{E} \left[\langle \langle \mathcal{O}(z^{(\ell+1)}) \rangle \rangle_{\widehat{G}^{(\ell+1)}} \right] \mathbb{E} \left[\sigma'_{j; \alpha_3}^{(\ell)} \sigma'_{j; \alpha_4}^{(\ell)} \widehat{H}_{jj; \alpha_3 \alpha_4}^{(\ell)} \right] \right\} \\ &\quad + \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{j_3, j_4=1}^{n_\ell} \sum_{\beta_3, \beta_4, \gamma_3, \gamma_4} \mathbb{E} \left[\langle \langle \left(z_{i_3; \beta_3}^{(\ell+1)} z_{i_4; \beta_4}^{(\ell+1)} - \delta_{i_3 i_4} \widehat{G}_{\beta_3 \beta_4}^{(\ell+1)} \right) \mathcal{O}(z^{(\ell+1)}) \rangle \rangle_{\widehat{G}^{(\ell+1)}} \right. \\ &\quad \left. \times \widehat{G}_{(\ell+1)}^{\beta_3 \gamma_3} \widehat{G}_{(\ell+1)}^{\beta_4 \gamma_4} \sigma_{j_3; \gamma_3}^{(\ell)} \sigma_{j_4; \gamma_4}^{(\ell)} \sigma'_{j_3; \alpha_3}^{(\ell)} \sigma'_{j_4; \alpha_4}^{(\ell)} \widehat{H}_{j_3 j_4; \alpha_3 \alpha_4}^{(\ell)} \right]. \end{aligned} \quad (8.66)$$

这里在第一项中还回顾了度量涨落 (4.74) 的定义. 从这个一般表达式中已经可以得到两条重要启示.

第一，令 $\mathcal{O} = z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)}$ ，便能用第 ℓ 层变量表示基本的第 $(\ell+1)$ 层交叉相关：

$$\begin{aligned}
 & \mathbb{E} \left[z_{i_1; \alpha_1}^{(\ell+1)} z_{i_2; \alpha_2}^{(\ell+1)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] \\
 &= \delta_{i_1 i_2} \delta_{i_3 i_4} \left\{ \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} \mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Delta G}_{\alpha_3 \alpha_4}^{(\ell+1)} \right] + C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \sigma_{j; \alpha_3}'^{(\ell)} \sigma_{j; \alpha_4}'^{(\ell)} \widehat{H}_{jj; \alpha_3 \alpha_4}^{(\ell)} \right] \right\} \\
 &+ \delta_{i_1 i_3} \delta_{i_2 i_4} \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{k; \alpha_2}^{(\ell)} \sigma_{j; \alpha_3}'^{(\ell)} \sigma_{k; \alpha_4}'^{(\ell)} \widehat{H}_{jk; \alpha_3 \alpha_4}^{(\ell)} \right] \\
 &+ \delta_{i_1 i_4} \delta_{i_2 i_3} \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_2}^{(\ell)} \sigma_{k; \alpha_1}^{(\ell)} \sigma_{j; \alpha_3}'^{(\ell)} \sigma_{k; \alpha_4}'^{(\ell)} \widehat{H}_{jk; \alpha_3 \alpha_4}^{(\ell)} \right] \\
 &\equiv \frac{1}{n_\ell} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(\ell+1)} + \delta_{i_1 i_3} \delta_{i_2 i_4} F_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(\ell+1)} + \delta_{i_1 i_4} \delta_{i_2 i_3} F_{\alpha_1 \alpha_4 \alpha_2 \alpha_3}^{(\ell+1)} \right], \tag{8.67}
 \end{aligned}$$

最后一行把交叉相关分解为两个只带样本指标的张量，正如第二层的 (8.37) 所做的那样。令前后两个表达式相等，可见这些张量由下列第 ℓ 层期望定义：

$$\frac{1}{n_\ell} D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(\ell+1)} \equiv \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} \mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Delta G}_{\alpha_3 \alpha_4}^{(\ell+1)} \right] \tag{8.68}$$

$$\begin{aligned}
 &+ C_W^{(\ell+1)} \left(\frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\widehat{\Delta G}_{\alpha_1 \alpha_2}^{(\ell+1)} \sigma_{j; \alpha_3}'^{(\ell)} \sigma_{j; \alpha_4}'^{(\ell)} \widehat{H}_{jj; \alpha_3 \alpha_4}^{(\ell)} \right] \right), \\
 \frac{1}{n_\ell} F_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(\ell+1)} &\equiv \left(C_W^{(\ell+1)} \right)^2 \left(\frac{1}{n_\ell^2} \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{k; \alpha_2}^{(\ell)} \sigma_{j; \alpha_3}'^{(\ell)} \sigma_{k; \alpha_4}'^{(\ell)} \widehat{H}_{jk; \alpha_3 \alpha_4}^{(\ell)} \right] \right). \tag{8.69}
 \end{aligned}$$

在揭示第二条启示之后，我们再回来计算最后两个表达式，从而推导这两个交叉相关张量的递推关系。

第二，再从一般交叉相关子 (8.66) 出发，把计算在 $1/n$ 的领先阶再向前推进一点。关键步骤是对高斯期望作微扰展开——正如之前在使用 Schwinger–Dyson 方程 (4.55) 前展开随机高斯分布 (4.56) 那样——得到

$$\begin{aligned}
 & \langle\langle \mathcal{O}(z^{(\ell+1)}) \rangle\rangle_{\widehat{G}^{(\ell+1)}} \\
 &= \langle\langle \mathcal{O}(z^{(\ell+1)}) \rangle\rangle_{G^{(\ell+1)}} \\
 &+ \frac{1}{2} \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left\langle\left\langle \sum_m \left(z_{m; \beta_1}^{(\ell+1)} z_{m; \beta_2}^{(\ell+1)} - G_{\beta_1 \beta_2}^{(\ell+1)} \right) \mathcal{O}(z^{(\ell+1)}) \right\rangle\right\rangle_{G^{(\ell+1)}} G_{(\ell+1)}^{\beta_1 \gamma_1} G_{(\ell+1)}^{\beta_2 \gamma_2} \widehat{\Delta G}_{\gamma_1 \gamma_2}^{(\ell+1)} + O(\Delta^2). \tag{8.70}
 \end{aligned}$$

把它代回 (8.66)，选取领先阶部分，并使用定义 (8.68) 与 (8.69)，得到

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell)}) \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell)} \right] \\ &= \delta_{i_3 i_4} \frac{1}{n_{\ell-1}} \left[\frac{1}{2} \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left\langle \left\langle \sum_{m=1}^{n_\ell} \left(z_{m; \beta_1}^{(\ell)} z_{m; \beta_2}^{(\ell)} - G_{\beta_1 \beta_2}^{(\ell)} \right) \mathcal{O}(z^{(\ell)}) \right\rangle \right\rangle_{G^{(\ell)}} G_{\beta_1 \gamma_1}^{(\ell)} G_{\beta_2 \gamma_2}^{(\ell)} \right] D_{\gamma_1 \gamma_2 \alpha_3 \alpha_4}^{(\ell)} \\ &+ \frac{1}{n_{\ell-1}} \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left\langle \left\langle \left(z_{i_3; \beta_1}^{(\ell)} z_{i_4; \beta_2}^{(\ell)} - \delta_{i_3 i_4} G_{\beta_1 \beta_2}^{(\ell)} \right) \mathcal{O}(z^{(\ell)}) \right\rangle \right\rangle_{G^{(\ell)}} G_{\beta_1 \gamma_1}^{(\ell)} G_{\beta_2 \gamma_2}^{(\ell)} F_{\gamma_1 \alpha_3 \gamma_2 \alpha_4}^{(\ell)} \\ &+ O\left(\frac{1}{n^2}\right), \end{aligned} \quad (8.71)$$

其中还把层指标处处从 $(\ell+1)$ 重标记为 ℓ ，以便稍后代入。¹⁴¹ 这个结果表明，这些更一般的交叉相关与基本交叉相关 (8.67) 一样，都由同一对张量 $D^{(\ell)}$ 与 $F^{(\ell)}$ 支配。因而，只要找出并求解 $D^{(\ell)}$ 与 $F^{(\ell)}$ 的递推关系，就能计算所有交叉相关子。下面转向这一任务。

D-递推

从 $D^{(\ell+1)}$ 的表达式 (8.68) 出发，代入随机度量的定义 (8.49)，得到

$$\begin{aligned} D_{\alpha_1 \alpha_2 \alpha_3 \alpha_4}^{(\ell+1)} &= C_W^{(\ell+1)} \frac{1}{n_\ell} \sum_{j,k=1}^{n_\ell} \text{Cov} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)}, \lambda_W^{(\ell+1)} \sigma_{k; \alpha_3}^{(\ell)} \sigma_{k; \alpha_4}^{(\ell)} + C_W^{(\ell+1)} H_{\alpha_3 \alpha_4}^{(\ell)} \sigma'_{k; \alpha_3}^{(\ell)} \sigma'_{k; \alpha_4}^{(\ell)} \right] \\ &+ \left(C_W^{(\ell+1)} \right)^2 \frac{1}{n_\ell} \sum_{j,k=1}^{n_\ell} \text{Cov} \left[\sigma_{j; \alpha_1}^{(\ell)} \sigma_{j; \alpha_2}^{(\ell)}, \sigma'_{k; \alpha_3}^{(\ell)} \sigma'_{k; \alpha_4}^{(\ell)} \widehat{\Delta H}_{kk; \alpha_3 \alpha_4}^{(\ell)} \right] + O\left(\frac{1}{n}\right), \end{aligned} \quad (8.72)$$

这里再次把第 ℓ 层 NTK 分解为均值部分与涨落部分。可以看到，这里有两类项：单个神经元上的协方差 $j = k$ ，以及成对神经元之间的协方差 $j \neq k$ 。

对于 $j = k$ 的单神经元贡献，在领先阶得到与第二层 (8.38) 相同的贡献¹⁴²

$$C_W^{(\ell+1)} \left[\left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \right] + O\left(\frac{1}{n}\right). \quad (8.73)$$

这里的辅助随机矩阵 $\widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)}$ 定义为

$$\widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} \equiv \lambda_W^{(\ell+1)} \sigma_{\alpha_1}^{(\ell)} \sigma_{\alpha_2}^{(\ell)} + C_W^{(\ell+1)} H_{\alpha_1 \alpha_2}^{(\ell)} \sigma'_{\alpha_1}^{(\ell)} \sigma'_{\alpha_2}^{(\ell)}, \quad (8.74)$$

它只是第二层定义 (8.34) 的推广。提醒一下，不带帽的矩阵 $H_{\alpha_1 \alpha_2}^{(\ell)}$ 是 NTK 均值，并非随机变量，可以安全地移出高斯期望 $\langle \cdot \rangle_{G^{(\ell)}}$ 。这意味着，作为随机变量， $\widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)}$ 只依赖第 ℓ 层预激活。

接下来，对于 (8.72) 中 $j \neq k$ 的成对神经元贡献，第一项可由层内公式 (8.41) 计算，得到

$$\frac{n_\ell}{4n_{\ell-1}} C_W^{(\ell+1)} \sum_{\gamma_1, \gamma_2, \gamma_3, \gamma_4} V_{(\ell)}^{(\gamma_1 \gamma_2)(\gamma_3 \gamma_4)} \left\langle \left(z_{\gamma_1} z_{\gamma_2} - G_{\gamma_1 \gamma_2}^{(\ell)} \right) \sigma_{\alpha_1} \sigma_{\alpha_2} \right\rangle_{G^{(\ell)}} \left\langle \left(z_{\gamma_3} z_{\gamma_4} - G_{\gamma_3 \gamma_4}^{(\ell)} \right) \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}}. \quad (8.75)$$

¹⁴¹你可能会担心 (8.71) 第一个高斯期望中的求和 $\sum_{m=1}^{n_\ell}$ 。然而，由于高斯分解，只要可观测量 $\mathcal{O}$ 仅依赖有限个神经元，这一期望就始终保持一阶。

¹⁴²次领先的 $O(1/n)$ 部分既包含分布非高斯部分的贡献，也包含前一层交叉相关的贡献。

与此同时，第二项中的协方差可展开为

$$\begin{aligned}
 & \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \\
 &= \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] - \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \\
 &= \frac{1}{2n_{\ell-1}} \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left\langle \left(z_{\beta_1} z_{\beta_2} - G_{\beta_1\beta_2}^{(\ell)} \right) \sigma_{\alpha_1} \sigma_{\alpha_2} \right\rangle_{G^{(\ell)}} \left\langle \sigma_{\alpha_3}' \sigma_{\alpha_4}' \right\rangle_{G^{(\ell)}} G_{(\ell)}^{\beta_1\gamma_1} G_{(\ell)}^{\beta_2\gamma_2} D_{\gamma_1\gamma_2\alpha_3\alpha_4}^{(\ell)} + O\left(\frac{1}{n^2}\right),
 \end{aligned} \tag{8.76}$$

最后一行分别对可观测量 $\mathcal{O} = \sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{k;\alpha_3}'^{(\ell)} \sigma_{k;\alpha_4}'^{(\ell)}$ 和 $\mathcal{O} = \sigma_{k;\alpha_3}'^{(\ell)} \sigma_{k;\alpha_4}'^{(\ell)}$ 使用了交叉相关公式 (8.71). 把这些贡献与第一部分 (8.73) 合并，得到所需递推关系：

$$\begin{aligned}
 & D_{\alpha_1\alpha_2\alpha_3\alpha_4}^{(\ell+1)} \\
 &= C_W^{(\ell+1)} \left(\left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \widehat{\Omega}_{\alpha_3\alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} - \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{G^{(\ell)}} \left\langle \widehat{\Omega}_{\alpha_3\alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \right) \\
 &+ \frac{n_\ell}{4n_{\ell-1}} C_W^{(\ell+1)} \sum_{\gamma_1, \gamma_2, \gamma_3, \gamma_4} V_{(\ell)}^{(\gamma_1\gamma_2)(\gamma_3\gamma_4)} \left\langle \left(z_{\gamma_1} z_{\gamma_2} - G_{\gamma_1\gamma_2}^{(\ell)} \right) \sigma_{\alpha_1} \sigma_{\alpha_2} \right\rangle_{G^{(\ell)}} \left\langle \left(z_{\gamma_3} z_{\gamma_4} - G_{\gamma_3\gamma_4}^{(\ell)} \right) \widehat{\Omega}_{\alpha_3\alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \\
 &+ \frac{n_\ell}{2n_{\ell-1}} \left(C_W^{(\ell+1)} \right)^2 \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} D_{\gamma_1\gamma_2\alpha_3\alpha_4}^{(\ell)} \left\langle \left(z_{\beta_1} z_{\beta_2} - G_{\beta_1\beta_2}^{(\ell)} \right) \sigma_{\alpha_1} \sigma_{\alpha_2} \right\rangle_{G^{(\ell)}} G_{(\ell)}^{\beta_1\gamma_1} G_{(\ell)}^{\beta_2\gamma_2} \left\langle \sigma_{\alpha_3}' \sigma_{\alpha_4}' \right\rangle_{G^{(\ell)}} \\
 &+ O\left(\frac{1}{n}\right).
 \end{aligned} \tag{8.77}$$

有趣的是，在领先阶，第 $(\ell+1)$ 层的 D 型交叉相关会把第 ℓ 层的 D 型相关与四点顶角 $V^{(\ell)}$ 混合，却不会与 F 型交叉相关或 NTK 方差的任何部分混合。

F -递推

从 $F^{(\ell+1)}$ 的表达式 (8.69) 出发，把 NTK 分解为均值与涨落，得到

$$\begin{aligned}
 F_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell+1)} &= \left(C_W^{(\ell+1)} \right)^2 \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_3}'^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \sigma_{j;\alpha_4}'^{(\ell)} \right] H_{\alpha_3\alpha_4}^{(\ell)} \\
 &+ \left(C_W^{(\ell+1)} \right)^2 \frac{1}{n_\ell} \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_3}'^{(\ell)} \sigma_{k;\alpha_2}^{(\ell)} \sigma_{k;\alpha_4}'^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right].
 \end{aligned} \tag{8.78}$$

在领先阶，第一项直接变成单神经元高斯期望；第二项可用交叉相关公式 (8.71) 计算，其中 $j=k$ 的对角和为 $O(1/n)$ 阶，可以忽略，而 $j \neq k$ 的非对角和给出含 $F^{(\ell)}$ 的项。合并起来得到

$$\begin{aligned}
 F_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell+1)} &= \left(C_W^{(\ell+1)} \right)^2 \left\langle \sigma_{\alpha_1} \sigma_{\alpha_2} \sigma_{\alpha_3}' \sigma_{\alpha_4}' \right\rangle_{G^{(\ell)}} H_{\alpha_3\alpha_4}^{(\ell)} \\
 &+ \frac{n_\ell}{n_{\ell-1}} \left(C_W^{(\ell+1)} \right)^2 \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left\langle \sigma_{\alpha_1} \sigma_{\alpha_3}' z_{\beta_1} \right\rangle_{G^{(\ell)}} \left\langle \sigma_{\alpha_2} \sigma_{\alpha_4}' z_{\beta_2} \right\rangle_{G^{(\ell)}} G_{(\ell)}^{\beta_1\gamma_1} G_{(\ell)}^{\beta_2\gamma_2} F_{\gamma_1\alpha_3\gamma_2\alpha_4}^{(\ell)} \\
 &+ O\left(\frac{1}{n}\right).
 \end{aligned} \tag{8.79}$$

与前面的 D 递推一样，第一项已经出现在第二层的 $F^{(2)}$ (8.39) 中，而第二项则是前一层 ℓ 中存在涨落 NTK 的直接结果。此外还可看到，在领先阶， F 型交叉相关完全不会与其他任何有限宽度张量混合。

最后，在讨论 NTK 方差之前，注意 $D^{(\ell)}$ 与 $F^{(\ell)}$ 的递推关系，结合第一层 NTK 为确定性所给出的初始条件 $D^{(1)} = F^{(1)} = 0$ ，保证二者始终保持一阶。交叉相关分解 (8.67) 中有因子 $1/n_\ell$ ，再结合交叉相关公式 (8.71) 所概括的“第二条启示”，这意味着任何交叉相关都在 $1/n$ 展开中受到压低，并在严格的无限宽极限下恒等于零。

8.3.3 NTK 方差

现在终于来 emph 斩杀猛兽——NTK 方差。与 NTK-预激活交叉相关类似，由于前一层存在非平凡的层内相关 (8.41) 与涨落的 NTK (8.58)，更深层中的 NTK 方差计算不同于第二层计算。

NTK 方差由 NTK 涨落的期望大小给出：

$$\mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] = \text{Cov} \left[\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)}, \widehat{H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right]. \quad (8.80)$$

计算伊始，把 NTK 前向方程 (8.12) 代入这个定义式，再积掉权重 $W^{(\ell+1)}$ ；由于它们是独立随机变量，这一步很容易。尽管项数很多，代数运算大多直接：

$$\begin{aligned} & \mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell+1)} \right] \\ &= \delta_{i_1 i_2} \delta_{i_3 i_4} \frac{1}{n_\ell^2} \sum_{j,k=1}^{n_\ell} \left\{ \left(\lambda_W^{(\ell+1)} \right)^2 \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \right. \\ & \quad + \left(\lambda_W^{(\ell+1)} \right) C_W^{(\ell+1)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{H}_{kk;\alpha_3 \alpha_4}^{(\ell)} \right] \\ & \quad + \left(\lambda_W^{(\ell+1)} \right) C_W^{(\ell+1)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \widehat{H}_{jj;\alpha_1 \alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ & \quad \left. + \left(C_W^{(\ell+1)} \right)^2 \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \widehat{H}_{jj;\alpha_1 \alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{H}_{kk;\alpha_3 \alpha_4}^{(\ell)} \right] \right\} \\ & \quad + \delta_{i_1 i_3} \delta_{i_2 i_4} \left(C_W^{(\ell+1)} \right)^2 \frac{1}{n_\ell^2} \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{k;\alpha_2}^{(\ell)} \widehat{H}_{jk;\alpha_1 \alpha_2}^{(\ell)} \sigma_{j;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{H}_{jk;\alpha_3 \alpha_4}^{(\ell)} \right] \\ & \quad + \delta_{i_1 i_4} \delta_{i_2 i_3} \left(C_W^{(\ell+1)} \right)^2 \frac{1}{n_\ell^2} \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{k;\alpha_2}^{(\ell)} \widehat{H}_{jk;\alpha_1 \alpha_2}^{(\ell)} \sigma_{k;\alpha_3}^{(\ell)} \sigma_{j;\alpha_4}^{(\ell)} \widehat{H}_{kj;\alpha_3 \alpha_4}^{(\ell)} \right]. \end{aligned} \quad (8.81)$$

得到最后三项时，应当对四个 $W^{(\ell+1)}$ 的两对 Wick 缩并作三种不同配对：一种在同一个 NTK 内部，另外两种跨越两个 NTK。

观察 (8.81) 中 Kronecker delta 的神经元指标模式，提示我们再次把 NTK 方差分解为两个张量：

$$\begin{aligned} & \mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)} \widehat{\Delta H}_{i_3 i_4; \alpha_3 \alpha_4}^{(\ell)} \right] \\ & \equiv \frac{1}{n_{\ell-1}} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell)} + \delta_{i_1 i_3} \delta_{i_2 i_4} B_{\alpha_1 \alpha_3 \alpha_2 \alpha_4}^{(\ell)} + \delta_{i_1 i_4} \delta_{i_2 i_3} B_{\alpha_1 \alpha_4 \alpha_2 \alpha_3}^{(\ell)} \right], \end{aligned} \quad (8.82)$$

正如之前对第二层所作的分解 (8.31). 这里预先提出因子 $1/n_{\ell-1}$, 因为预计总方差与第二层一样为 $O(1/n)$. 暂时可把这个参数化视为一种拟设; 很快将递归证明, 随着网络宽度增加, $A_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell)}$ 与 $B_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell)}$ 始终保持一阶.

现在求出 $A^{(\ell)}$ 与 $B^{(\ell)}$ 的逐层递推关系.

B-递推

先从较简单的 B 递推开始. 考虑 (8.81), 并牢记分解 (8.82), 可见 $B^{(\ell+1)}$ 由下列第 ℓ 层期望给出:

$$B_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell+1)} = \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{j,k=1}^{n_\ell} \mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \widehat{H}_{jk;\alpha_1\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right]. \quad (8.83)$$

现在应当已经熟悉, (8.83) 中的二重求和分成两类项: $j = k$ 的对角项与 $j \neq k$ 的非对角项.

对于对角部分, 领先贡献来自 NTK 均值:

$$\begin{aligned} & \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{j=1}^{n_\ell} \mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{j;\alpha_4}^{(\ell)} \right] H_{\alpha_1\alpha_2}^{(\ell)} H_{\alpha_3\alpha_4}^{(\ell)} + O\left(\frac{1}{n}\right) \\ &= \left(C_W^{(\ell+1)}\right)^2 \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} H_{\alpha_1\alpha_2}^{(\ell)} H_{\alpha_3\alpha_4}^{(\ell)} + O\left(\frac{1}{n}\right), \end{aligned} \quad (8.84)$$

这与第二层的结果 (8.33) 类似.¹⁴³

对于 (8.83) 的非对角部分, NTK 均值消失, 领先贡献来自 NTK 涨落:

$$\left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{\substack{j,k=1 \\ j \neq k}}^{n_\ell} \mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right]. \quad (8.85)$$

由于其中含两个 NTK 涨落, 该期望已经是 $O(\Delta^2)$ 阶; 因此忽略 $O(\Delta^3)$ 阶的更高阶相关后, 有

$$\begin{aligned} & \mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &= \mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (8.86)$$

这一分解的详细解释见脚注.¹⁴⁴ 随后, 使用 NTK 方差的分解 (8.82), 并以类似 (4.63)

¹⁴³ 同样, 次领先的 $O(1/n)$ 部分既包含非高斯分布的贡献, 也包含前一层交叉相关的贡献.

¹⁴⁴ 更详细地说, 可把这里的做法理解为: 把 $\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)}$ 分成均值 $\mathbb{E} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \right]$ 与涨落; 由于期望中已经含有两个涨落 $\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)}$, 后一个涨落部分贡献 $O(\Delta^3)$, 因而可以忽略.

换一种详细说法, 可以把期望 (8.86) 看成三个随机变量 $\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{k;\alpha_2}^{(\ell)} \sigma'_{j;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)}$ 、 $\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)}$ 与 $\widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)}$

的逻辑计算非对角激活的四点相关子，得到

$$\begin{aligned} & \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{\substack{j,k=1 \\ j \neq k}}^{n_\ell} \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] + O\left(\frac{1}{n}\right) \\ &= \left(C_W^{(\ell+1)}\right)^2 \langle \sigma'_{\alpha_1} \sigma'_{\alpha_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\alpha_2} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} \frac{n_\ell}{n_{\ell-1}} B_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell)} + O\left(\frac{1}{n}\right). \end{aligned} \quad (8.88)$$

把对角贡献 (8.84) 与非对角贡献 (8.88) 一同代回 (8.83)，得到 B 递推：

$$\begin{aligned} B_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell+1)} &= \left(C_W^{(\ell+1)}\right)^2 \left[\langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} H_{\alpha_1\alpha_2}^{(\ell)} H_{\alpha_3\alpha_4}^{(\ell)} \right. \\ &\quad \left. + \left(\frac{n_\ell}{n_{\ell-1}}\right) \langle \sigma'_{\alpha_1} \sigma'_{\alpha_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\alpha_2} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} B_{\alpha_1\alpha_3\alpha_2\alpha_4}^{(\ell)} \right] + O\left(\frac{1}{n}\right). \end{aligned} \quad (8.89)$$

正如所承诺的，递归可见 $B^{(\ell)}$ 是一阶量。此外，在领先阶，这个 B 型 NTK 方差不会与任何其他有限宽度张量混合。

A-递推

现在确定 A 递推。再次令 NTK 方差表达式 (8.81) 与 A/B 分解 (8.82) 相等，可见 $A^{(\ell+1)}$ 由下列第 ℓ 层协方差给出：

$$\begin{aligned} A_{(\alpha_1\alpha_2)(\alpha_3\alpha_4)}^{(\ell+1)} &= \frac{1}{n_\ell} \sum_{j,k=1}^{n_\ell} \left\{ \left(\lambda_W^{(\ell+1)}\right)^2 \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \right. \\ &\quad + \lambda_W^{(\ell+1)} C_W^{(\ell+1)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &\quad + \lambda_W^{(\ell+1)} C_W^{(\ell+1)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \widehat{H}_{jj;\alpha_1\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ &\quad \left. + \left(C_W^{(\ell+1)}\right)^2 \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)} \widehat{H}_{jj;\alpha_1\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \widehat{H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \right\}. \end{aligned} \quad (8.90)$$

的相关子，并将其分解为一点与两点相关子：

$$\begin{aligned} & \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &= \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &\quad + \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &\quad + \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \\ &\quad + \mathbb{E} \left[\sigma'_{j;\alpha_1}(\ell) \sigma'_{k;\alpha_2}(\ell) \sigma'_{j;\alpha_3}(\ell) \sigma'_{k;\alpha_4}(\ell) \widehat{\Delta H}_{jk;\alpha_3\alpha_4}^{(\ell)} \right] \mathbb{E} \left[\widehat{\Delta H}_{jk;\alpha_1\alpha_2}^{(\ell)} \right] + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (8.87)$$

其中 $O(1/n^2)$ 部分包含该分解的连通部分。因为 NTK 涨落均值为零，在此阶只有第二项保留下来。

正如此前多次所见，我们把 (8.90) 中的二重求和分成两类项：单个神经元上 $j = k$ 的对角项，以及成对神经元上 $j \neq k$ 的非对角项。

与 B 递推一样， $j = k$ 对角部分的领先贡献来自 NTK 均值，并与第二层的结果 (8.32) 相同：

$$\left\langle \widehat{\Omega}_{\alpha_1\alpha_2}^{(\ell+1)} \widehat{\Omega}_{\alpha_3\alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} - \left\langle \widehat{\Omega}_{\alpha_1\alpha_2}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \left\langle \widehat{\Omega}_{\alpha_3\alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} + O\left(\frac{1}{n}\right), \quad (8.91)$$

其中辅助随机张量 $\widehat{\Omega}_{\alpha_1\alpha_2}^{(\ell+1)}$ 的定义见 (8.74).¹⁴⁵

剩下 (8.90) 中 $j \neq k$ 的非对角部分。这里既有来自 NTK 均值的领先贡献，也有来自 NTK 涨落的领先贡献。均值贡献可通过替换 $\widehat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)} \rightarrow \delta_{i_1 i_2} H_{\alpha_1 \alpha_2}^{(\ell)}$ 得到：

$$\begin{aligned} \frac{1}{n_\ell} \sum_{\substack{j,k=1 \\ j \neq k}}^{n_\ell} \Bigg\{ & \left(\lambda_W^{(\ell+1)} \right)^2 \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ & + \lambda_W^{(\ell+1)} C_W^{(\ell+1)} H_{\alpha_3\alpha_4}^{(\ell)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma'_{k;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \right] \\ & + \lambda_W^{(\ell+1)} C_W^{(\ell+1)} H_{\alpha_1\alpha_2}^{(\ell)} \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ & + \left(C_W^{(\ell+1)} \right)^2 H_{\alpha_1\alpha_2}^{(\ell)} H_{\alpha_3\alpha_4}^{(\ell)} \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)}, \sigma'_{k;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \right] \Bigg\}. \end{aligned} \quad (8.92)$$

这四个协方差都能用层内公式 (8.41) 计算。经过少量代数，在领先阶得到

$$\frac{n_\ell}{4n_{\ell-1}} \sum_{\gamma_1, \gamma_2, \gamma_3, \gamma_4} V_{(\ell)}^{(\gamma_1 \gamma_2)(\gamma_3 \gamma_4)} \left\langle (z_{\gamma_1} z_{\gamma_2} - G_{\gamma_1 \gamma_2}^{(\ell)}) \widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \left\langle (z_{\gamma_3} z_{\gamma_4} - G_{\gamma_3 \gamma_4}^{(\ell)}) \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \quad (8.93)$$

这里再次使用了 $\widehat{\Omega}_{\alpha_1\alpha_2}^{(\ell+1)}$ 的定义 (8.74)。

最后剩下来自 NTK 涨落的非对角贡献；若把它们详尽得令人痛苦地写出，则为

$$\begin{aligned} \frac{1}{n_\ell} \sum_{\substack{j,k=1 \\ j \neq k}}^{n_\ell} \Bigg\{ & \left(\lambda_W^{(\ell+1)} \right) C_W^{(\ell+1)} \text{Cov} \left[\sigma_{j;\alpha_1}^{(\ell)} \sigma_{j;\alpha_2}^{(\ell)}, \sigma'_{k;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \\ & + \left(\lambda_W^{(\ell+1)} \right) C_W^{(\ell+1)} \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)} \widehat{\Delta H}_{jj;\alpha_1\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ & + \left(C_W^{(\ell+1)} \right)^2 H_{\alpha_1\alpha_2}^{(\ell)} \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)}, \sigma'_{k;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \\ & + \left(C_W^{(\ell+1)} \right)^2 H_{\alpha_3\alpha_4}^{(\ell)} \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)} \widehat{\Delta H}_{jj;\alpha_1\alpha_2}^{(\ell)}, \sigma_{k;\alpha_3}^{(\ell)} \sigma_{k;\alpha_4}^{(\ell)} \right] \\ & + \left(C_W^{(\ell+1)} \right)^2 \text{Cov} \left[\sigma'_{j;\alpha_1}^{(\ell)} \sigma'_{j;\alpha_2}^{(\ell)} \widehat{\Delta H}_{jj;\alpha_1\alpha_2}^{(\ell)}, \sigma'_{k;\alpha_3}^{(\ell)} \sigma'_{k;\alpha_4}^{(\ell)} \widehat{\Delta H}_{kk;\alpha_3\alpha_4}^{(\ell)} \right] \Bigg\}. \end{aligned} \quad (8.94)$$

¹⁴⁵再次说明，次领先的 $O(1/n)$ 部分既包含非高斯分布的贡献，也包含前一层交叉相关的贡献，现在还包含前一层 NTK 方差的贡献。

最后一项含两个 NTK 涨落，可用与 B 递推中 (8.86) 类似的方法计算，¹⁴⁶得到

$$\left(C_W^{(\ell+1)}\right)^2 \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(\ell)}} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} \frac{n_\ell}{n_{\ell-1}} A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell)} + O\left(\frac{1}{n}\right). \quad (8.96)$$

而 (8.94) 中仅含单个 NTK 涨落的其余四个协方差，在结构上与 (8.76) 完全相同，因此把细节留给你和你的羊皮卷。

现在回顾 $A^{(\ell+1)}$ 表达式的所有组成部分：对角贡献 (8.91)；以及来自 NTK 均值 (8.93)、两个 NTK 涨落的协方差 (8.96) 和羊皮卷上四个协方差的非对角贡献。汇集这些部分，得到 A 递推：

$$\begin{aligned} & A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell+1)} \\ &= \left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} - \left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} \right\rangle_{G^{(\ell)}} \\ &+ \frac{n_\ell}{4n_{\ell-1}} \sum_{\gamma_1, \gamma_2, \gamma_3, \gamma_4} V_{(\ell)}^{(\gamma_1 \gamma_2)(\gamma_3 \gamma_4)} \left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} (z_{\gamma_1} z_{\gamma_2} - G_{\gamma_1 \gamma_2}^{(\ell)}) \right\rangle_{G^{(\ell)}} \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} (z_{\gamma_3} z_{\gamma_4} - G_{\gamma_3 \gamma_4}^{(\ell)}) \right\rangle_{G^{(\ell)}} \\ &+ \frac{n_\ell}{n_{\ell-1}} \left(C_W^{(\ell+1)}\right)^2 \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(\ell)}} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} A_{(\alpha_1 \alpha_2)(\alpha_3 \alpha_4)}^{(\ell)} \\ &+ \frac{n_\ell}{n_{\ell-1}} \frac{C_W^{(\ell+1)}}{2} \sum_{\beta_1, \beta_2, \gamma_1, \gamma_2} \left[\left\langle \widehat{\Omega}_{\alpha_1 \alpha_2}^{(\ell+1)} (z_{\beta_1} z_{\beta_2} - G_{\beta_1 \beta_2}^{(\ell)}) \right\rangle_{G^{(\ell)}} G_{(\ell)}^{\beta_1 \gamma_1} G_{(\ell)}^{\beta_2 \gamma_2} D_{\gamma_1 \gamma_2 \alpha_3 \alpha_4}^{(\ell)} \langle \sigma'_{\alpha_3} \sigma'_{\alpha_4} \rangle_{G^{(\ell)}} \right. \\ &\quad \left. + \left\langle \widehat{\Omega}_{\alpha_3 \alpha_4}^{(\ell+1)} (z_{\beta_1} z_{\beta_2} - G_{\beta_1 \beta_2}^{(\ell)}) \right\rangle_{G^{(\ell)}} G_{(\ell)}^{\beta_1 \gamma_1} G_{(\ell)}^{\beta_2 \gamma_2} D_{\gamma_1 \gamma_2 \alpha_1 \alpha_2}^{(\ell)} \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{G^{(\ell)}} \right] \\ &+ O\left(\frac{1}{n}\right). \end{aligned} \quad (8.97)$$

正如所承诺的，递归可见 $A^{(\ell)}$ 是一阶量。此外，有趣的是，在领先阶，第 $(\ell+1)$ 层 NTK 方差的这个 A 型贡献会与第 ℓ 层的四点顶角 $V^{(\ell)}$ 及交叉相关 $D^{(\ell)}$ 混合，却不会与 $B^{(\ell)}$ 或 $F^{(\ell)}$ 混合。

至此完成了对 NTK-预激活联合分布全部有限宽度效应的分析；领先 NTK-预激活交叉相关与 NTK 方差在大宽度展开中均按 $\sim 1/n$ 标度，并在无限宽极限下消失。¹⁴⁷ 这些量足以完全刻画基于梯度学习的领先有限宽度效应。

¹⁴⁶这里与先前 B 版本 (8.86) 的唯一区别是：由于现在计算协方差，需要减去

$$\mathbb{E} \left[\sigma'_{j; \alpha_1}^{(\ell)} \sigma'_{j; \alpha_2}^{(\ell)} \widehat{\Delta H}_{jj; \alpha_1 \alpha_2}^{(\ell)} \right] \mathbb{E} \left[\sigma'_{k; \alpha_3}^{(\ell)} \sigma'_{k; \alpha_4}^{(\ell)} \widehat{\Delta H}_{kk; \alpha_3 \alpha_4}^{(\ell)} \right] \quad (8.95)$$

这一项。然而它为 $O(1/n^2)$ 阶，因而可以忽略。

¹⁴⁷回顾第 2.3 节脚注 27 中的讨论，这意味着 NTK 在严格的无限宽极限下会自平均；在此极限中，网络参数任意一次实例化的 NTK 取值都是固定的，并等于系综均值。

第 9 章

初始化时 NTK 的有效理论

简言之，我们相信自己已经回应了 Minsky 与 Papert 的挑战，并且确实找到了一个足够有力的学习结果，足以证明他们对多层机器学习能力的悲观看法并不成立。

Rumelhart、Hinton 与 Williams [15]，超越因果时序地挺身回应 §5 中的批评。

上一章充满了方程、代数与积分的狂风暴雨，现在让我们花一点时间来衡量自己的期望值。

在 §8 中，我们的目标是确定初始化时给定层 ℓ 的 NTK-预激活联合分布： $p(z^{(\ell)}, \hat{H}^{(\ell)} | \mathcal{D})$ 。除了 §4 中为核 (4.118) 与四点顶角 (4.119) 推导的递推之外，这一分布中依赖数据的耦合与连通相关函数还会依照我们刚刚艰苦推导出的递推随深度流动：NTK 均值遵循 (8.63)，NTK-预激活交叉相关遵循 (8.77) 与 (8.79)，NTK 方差遵循 (8.89) 与 (8.97)。这种 RG 流分析告诉我们：NTK 在第一层是确定性对象 (§8.1)，在第二层发生随机涨落并产生交叉相关 (§8.2)，随后又在更深层继续积累涨落与交叉相关 (§8.3)。

既然我们已经彻底讨论了数学，本章终于可以考察这个联合分布的物理。以 §5 中对临界性与普适性的讨论为基础，我们首先为 NTK 的类似分析打下基础，同时突出上一章中与之相关的结果 (§9.1)。尤其是，我们将重点理解初始化超参数与训练超参数如何影响有限宽度下的梯度下降。我们会再次发现，深宽比 L/n 在控制有限宽度效应方面扮演主角；先考察尺度不变普适类 (§9.2)，再考察 $K^* = 0$ 普适类 (§9.3)。在这两种情形中，NTK 涨落与交叉相关的重要性都会随深度增长，使有限宽度相互作用在 NTK 的 RG 流下成为相关的。

最后，我们将介绍深度学习中臭名昭著的梯度爆炸与消失问题，并看到我们的临界性概念如何彻底缓解这一问题 (§9.4)。在这一语境下，我们还会说明偏置与权重的学习率应分别如何随网络深度缩放。

9.1 NTK 的临界性分析

先为我们的临界性分析搭好舞台。正如在 §5 中讨论预激活临界性时那样，本节始终把偏置方差 $C_b^{(\ell)}$ 与重缩放权重方差 $C_W^{(\ell)}$ 设为逐层均匀，

$$C_b^{(\ell)} = C_b, \quad C_W^{(\ell)} = C_W. \quad (9.1)$$

进一步仿照 §5.4, 我们考虑隐藏层宽度均匀的 MLP,

$$n_1 = \dots = n_{L-1} \equiv n, \quad (9.2)$$

这既是实践中的合理选择, 也能简化记号.

不过, 对于训练超参数, 我们暂时保留偏置学习率 $\lambda_b^{(\ell)}$ 与权重学习率 $\lambda_W^{(\ell)}$ 的层依赖性, 因为不同普适类需要不同的处理. 我们将在 §9.4 中探究这些超参数选择背后的一般原理.

下文只关注单输入统计中 $1/n$ 展开的领先贡献, 忽略次领先阶的次领先修正, 并把多输入分析留给读者私下消遣.

单输入的领先阶 NTK 递推

先从 NTK 均值递推开始. 与其他所有可观测量类似, $1/n$ 展开在 NTK 均值上诱导出如下级数展开:

$$H_{\alpha_1\alpha_2}^{(\ell)} = H_{\alpha_1\alpha_2}^{\{0\}(\ell)} + \frac{1}{n_{\ell-1}} H_{\alpha_1\alpha_2}^{\{1\}(\ell)} + \frac{1}{n_{\ell-1}^2} H_{\alpha_1\alpha_2}^{\{2\}(\ell)} + O\left(\frac{1}{n^3}\right). \quad (9.3)$$

正如我们把核 $K_{\alpha_1\alpha_2}^{(\ell)}$ 定义为均值度量 $G_{\alpha_1\alpha_2}^{(\ell)}$ 的无限宽度极限 (4.106), 现在也给 NTK 均值的领先 $O(1)$ 部分赋予一个专门符号,

$$\Theta_{\alpha_1\alpha_2}^{(\ell)} \equiv H_{\alpha_1\alpha_2}^{\{0\}(\ell)}, \quad (9.4)$$

并给它一个专门名称: **冻结 NTK**. 冻结 NTK 控制无限宽度极限下的训练动力学, 我们将在下一章中详细研究它.¹⁴⁸

现在取 NTK 均值递推 (8.63) 的领先部分, 便得到一个只涉及冻结 NTK 的递推,

$$\Theta_{\alpha_1\alpha_2}^{(\ell+1)} = \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \langle \sigma_{\alpha_1} \sigma_{\alpha_2} \rangle_{K^{(\ell)}} + C_W \langle \sigma'_{\alpha_1} \sigma'_{\alpha_2} \rangle_{K^{(\ell)}} \Theta_{\alpha_1\alpha_2}^{(\ell)}. \quad (9.5)$$

与此同时, 由于忽略了次领先贡献, 我们把关于均值度量 $G^{(\ell)}$ 的高斯期望换成了关于核 $K^{(\ell)}$ 的高斯期望. 最后专门取单输入情形, 只需去掉样本指标, 便得到这一递推的最终形式,

$$\Theta^{(\ell+1)} = \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} g(K^{(\ell)}) + \chi_{\perp}(K^{(\ell)}) \Theta^{(\ell)}, \quad (9.6)$$

其初始条件直接来自第一层 NTK 分析 (8.23),

$$\Theta^{(1)} = \lambda_b^{(1)} + \lambda_W^{(1)} \left(\frac{1}{n_0} \sum_{j=1}^{n_0} x_j^2 \right). \quad (9.7)$$

注意, 这里还使用了 §5 中的一个辅助函数和一个易感率.

¹⁴⁸ 文献中所谓的神经正切核或 NTK, 通常指这个确定性的无限宽度 NTK 均值 $\Theta_{\alpha_1\alpha_2}^{(\ell)}$. 由于我们主要关心有限宽度网络, 因而选择把随机对象 $\hat{H}_{i_1 i_2; \alpha_1 \alpha_2}^{(\ell)}$ 定义并称作 NTK. 为了向文献惯例让步, 我们用 NTK 的习用符号 Θ 表示冻结 NTK. (一个有用的记忆法是: Θ 里面冻结着一个 H .) 遗憾的是, 要到 §11 才能理解为什么把无限宽度 NTK 称为冻结的; 在那里, 我们将看到有限宽度效应如何解冻训练过程, 并使 NTK 运动起来. 而在本章中, 至少可以看到有限宽度涨落如何使它受到扰动.

为了方便起见,再回顾并重印我们最早在 §5 中推广的整套辅助函数——(5.5) 与 (5.52)——以及易感率——(5.50) 与 (5.51):

$$g(K) = \langle \sigma(z) \sigma(z) \rangle_K, \quad (9.8)$$

$$h(K) \equiv \frac{C_W}{4K^2} \langle \sigma'(z) \sigma'(z) (z^2 - K) \rangle_K = \frac{1}{2} \frac{d}{dK} \chi_\perp(K), \quad (9.9)$$

$$\chi_\parallel(K) = C_W g'(K) = \frac{C_W}{2K^2} \langle \sigma(z) \sigma(z) (z^2 - K) \rangle_K = \frac{C_W}{K} \langle z \sigma'(z) \sigma(z) \rangle_K, \quad (9.10)$$

$$\chi_\perp(K) = C_W \langle \sigma'(z) \sigma'(z) \rangle_K. \quad (9.11)$$

提醒一下,从 (9.10) 的中间表达式过渡到右端表达式时,应当使用分部积分.

对于其余递推,我们将快进这一过程,因为把多输入递推化为领先阶单输入递推的步骤虽值得注意,却多少有些机械: (i) 按照 (9.1) 去掉初始化超参数的层依赖性,并按照 (9.2) 令各层宽度均匀; (ii) 去掉所有样本指标; (iii) 分别用核 $K^{(\ell)}$ 与冻结 NTK $\Theta^{(\ell)}$ 替换均值度量 $G^{(\ell)}$ 和 NTK 均值 $H^{(\ell)}$; ¹⁴⁹ 然后 (iv) 代入辅助函数和易感率 (9.8)–(9.11). 最后这一步尤其有益,因为它让我们能够复用 §5 中关于这些函数深层渐近行为的结果.

还需要回顾辅助随机变量 (8.74) 的单输入领先阶表达式,

$$\hat{\Omega}^{(\ell+1)} \equiv \lambda_W^{(\ell+1)} \sigma(z) \sigma(z) + C_W \Theta^{(\ell)} \sigma'(z) \sigma'(z), \quad (9.12)$$

它出现在 $D^{(\ell)}$ 的递推 (8.77) 与 $A^{(\ell)}$ 的递推 (8.97) 中;不妨把这一步代入称为倒数第二步 (iii-b). 作这些代入时,请记住,乘在第二项上的冻结 NTK $\Theta^{(\ell)}$ 并非随机变量,因此可以把它从任何高斯期望中带出去.

此时,请再拿一卷羊皮纸,抄下表达式 (9.8)–(9.12),向前翻几页找到 $D^{(\ell)}$ 、 $F^{(\ell)}$ 、 $B^{(\ell)}$ 和 $A^{(\ell)}$ 各自的递推 (8.77)、(8.79)、(8.89) 与 (8.97) (或者,孩子们也许可以直接点击电子书里的公式引用,把公式复制到平板电脑上),再按照上述四步 (尽管有时暗中

¹⁴⁹严格说来,我们确实应该像对均值度量 $G^{(\ell)}$ 所作的 (4.106) 和对 NTK 均值 $H^{(\ell)}$ 所作的 (9.3) 那样,为有限宽度张量 $A^{(\ell)}$ 、 $B^{(\ell)}$ 、 $D^{(\ell)}$ 、 $F^{(\ell)}$ 作 $1/n$ 展开;还应恰当地使用为 $V^{(\ell)}$ 所作的展开 (4.105),把领先阶部分记为 $A^{\{0\}(\ell)}$ 等,并舍去次领先部分. 为了保持记号理智,我们不把这些记号强加给读者,不过这里针对这些张量的所有递推都应理解为指其领先阶部分. (核与冻结 NTK 比较特殊,因为这些无限宽度对象已得到学界的广泛研究,所以在这两个情形中,区分有限宽度对象与无限宽度部分十分重要.)

是五步) 流程 (i)–(iv) 化简. 完成后, 请确认所得结果与我们一致:

$$D^{(\ell+1)} = \chi_{\perp}^{(\ell)} \chi_{\parallel}^{(\ell)} D^{(\ell)} + \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right) \left[C_W^2 \langle \sigma(z) \sigma(z) \sigma(z) \sigma(z) \rangle_{K^{(\ell)}} - \left(C_W g^{(\ell)} \right)^2 + \left(\chi_{\parallel}^{(\ell)} \right)^2 V^{(\ell)} \right] \\ + \Theta^{(\ell)} \left[C_W^2 \langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} - C_W g^{(\ell)} \chi_{\perp}^{(\ell)} + 2h^{(\ell)} \chi_{\parallel}^{(\ell)} V^{(\ell)} \right], \quad (9.13)$$

$$F^{(\ell+1)} = \left(\chi_{\parallel}^{(\ell)} \right)^2 F^{(\ell)} + C_W^2 \langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} \Theta^{(\ell)}, \quad (9.14)$$

$$B^{(\ell+1)} = \left(\chi_{\perp}^{(\ell)} \right)^2 B^{(\ell)} + C_W^2 \langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} \left(\Theta^{(\ell)} \right)^2, \quad (9.15)$$

$$A^{(\ell+1)} = \left(\chi_{\perp}^{(\ell)} \right)^2 A^{(\ell)} + \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right)^2 \left[C_W^2 \langle \sigma(z) \sigma(z) \sigma(z) \sigma(z) \rangle_{K^{(\ell)}} - \left(C_W g^{(\ell)} \right)^2 + \left(\chi_{\parallel}^{(\ell)} \right)^2 V^{(\ell)} \right] \\ + 2 \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right) \Theta^{(\ell)} \left[C_W^2 \langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} - C_W g^{(\ell)} \chi_{\perp}^{(\ell)} + 2h^{(\ell)} \chi_{\parallel}^{(\ell)} V^{(\ell)} \right] \\ + 2 \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right) \chi_{\perp}^{(\ell)} \chi_{\parallel}^{(\ell)} D^{(\ell)} + 4h^{(\ell)} \chi_{\perp}^{(\ell)} \Theta^{(\ell)} D^{(\ell)} \\ + \left(\Theta^{(\ell)} \right)^2 \left[C_W^2 \langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} - \left(\chi_{\perp}^{(\ell)} \right)^2 + \left(2h^{(\ell)} \right)^2 V^{(\ell)} \right]. \quad (9.16)$$

这些递推的初始条件 (回顾第一层 NTK 完全是确定性的) 全部恒等于零, 即

$$A^{(1)} = B^{(1)} = D^{(1)} = F^{(1)} = 0. \quad (9.17)$$

此外, 对辅助函数和易感率, 我们还采用了如下简化记号:

$$g^{(\ell)} \equiv g(K^{(\ell)}), \quad h^{(\ell)} \equiv h(K^{(\ell)}), \quad \chi_{\parallel}^{(\ell)} \equiv \chi_{\parallel}(K^{(\ell)}), \quad \chi_{\perp}^{(\ell)} \equiv \chi_{\perp}(K^{(\ell)}), \quad (9.18)$$

其中隐去了核依赖性.

回顾四点顶角的单输入递推 (5.109), 还可以进一步化简 (9.13) 与 (9.16),

$$V^{(\ell+1)} = \left(\chi_{\parallel}^{(\ell)} \right)^2 V^{(\ell)} + C_W^2 \left[\langle \sigma(z) \sigma(z) \sigma(z) \sigma(z) \rangle_{K^{(\ell)}} - \left(g^{(\ell)} \right)^2 \right]. \quad (9.19)$$

继续盯着这些方程看, 便会浮现出稍微更紧凑的表达式:

$$D^{(\ell+1)} = \chi_{\perp}^{(\ell)} \chi_{\parallel}^{(\ell)} D^{(\ell)} + \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right) V^{(\ell+1)} \quad (9.20)$$

$$+ \Theta^{(\ell)} \left[C_W^2 \langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} - C_W g^{(\ell)} \chi_{\perp}^{(\ell)} + 2h^{(\ell)} \chi_{\parallel}^{(\ell)} V^{(\ell)} \right],$$

$$A^{(\ell+1)} = \left(\chi_{\perp}^{(\ell)} \right)^2 A^{(\ell)} - \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right)^2 V^{(\ell+1)} + 2 \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \right) D^{(\ell+1)} + 4h^{(\ell)} \chi_{\perp}^{(\ell)} \Theta^{(\ell)} D^{(\ell)} \\ + \left(\Theta^{(\ell)} \right)^2 \left[C_W^2 \langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} - \left(\chi_{\perp}^{(\ell)} \right)^2 + \left(2h^{(\ell)} \right)^2 V^{(\ell)} \right], \quad (9.21)$$

求解递推时, 你可能会发现这些公式更简单. 不过使用时请务必小心, 因为其右端同时出现了第 ℓ 层与第 $(\ell+1)$ 层的对象.

缩放律的相关性

本章余下部分将逐一求解五个领先阶单输入 NTK 递推 (9.6) 与 (9.13)–(9.16). (记住, 我们早在 §5 中就已经求解了核与四点顶角的单输入递推.) 求解这些递推时, 我们将发现每个可观测量都遵循缩放拟设 (5.93):

$$\begin{aligned}\mathcal{O}^{(\ell)} &= \left(\frac{1}{\ell}\right)^{p_{\mathcal{O}}} \left[c_{0,0} + c_{1,1} \left(\frac{\log \ell}{\ell}\right) + c_{1,0} \left(\frac{1}{\ell}\right) + c_{2,2} \left(\frac{\log^2 \ell}{\ell^2}\right) + \dots \right] \\ &= \left(\frac{1}{\ell}\right)^{p_{\mathcal{O}}} \left[\sum_{s=0}^{\infty} \sum_{q=0}^s c_{s,q} \left(\frac{\log^q \ell}{\ell^s}\right) \right].\end{aligned}\quad (9.22)$$

回顾一下, $p_{\mathcal{O}}$ 是临界指数, 对于给定的激活函数普适类而言具有普适性; 而常数 $c_{s,q}$ 则依赖于所考察的具体激活函数的一些细节.

为了正确理解这些可观测量的物理, 回顾 §5.4: 我们需要考察无量纲量. 对于控制 NTK 方差的两个张量, 应当用冻结 NTK 的平方作归一化,

$$\frac{A^{(\ell)}}{n(\Theta^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell}\right)^{p_A - 2p_{\Theta}} + \dots, \quad \frac{B^{(\ell)}}{n(\Theta^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell}\right)^{p_B - 2p_{\Theta}} + \dots, \quad (9.23)$$

而对于 NTK–预激活交叉相关, 则应当用一个冻结 NTK 因子和一个核因子作归一化,

$$\frac{D^{(\ell)}}{nK^{(\ell)}\Theta^{(\ell)}} \sim \frac{1}{n} \left(\frac{1}{\ell}\right)^{p_D - p_{\Theta} - p_0} + \dots, \quad \frac{F^{(\ell)}}{nK^{(\ell)}\Theta^{(\ell)}} \sim \frac{1}{n} \left(\frac{1}{\ell}\right)^{p_F - p_{\Theta} - p_0} + \dots, \quad (9.24)$$

其中 p_0 是单输入核 $K^{(\ell)}$ 的临界指数.

考察这些无量纲量后, 我们会发现甚至能够超越普适类的缩放律. 举一个具体例子, 回顾归一化的四点顶角 (5.128),

$$\frac{V^{(\ell)}}{n(K^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell}\right)^{p_V - 2p_0} + \dots, \quad (9.25)$$

它对尺度不变激活函数与 $K^* = 0$ 激活函数都给出了缩放律 (5.129),

$$p_V - 2p_0 = -1, \quad (9.26)$$

这一缩放律使我们能够把比值 ℓ/n 解释为控制预激活分布领先有限宽度行为的涌现尺度. 剧透警告: 以几乎相同的方式, 我们将发现缩放律

$$p_A - 2p_{\Theta} = -1, \quad p_B - 2p_{\Theta} = -1, \quad p_D - p_{\Theta} - p_0 = -1, \quad p_F - p_{\Theta} - p_0 = -1, \quad (9.27)$$

也同时适用于尺度不变普适类与 $K^* = 0$ 普适类. 因此, 我们将能够断定, NTK–预激活联合分布的所有领先有限宽度效应都是相关的, 并受同一个 ℓ/n 微扰截断控制. 这意味着, 我们能够有效描述宽度有限且 L/n 非零的现实深度网络的训练.

形式性：垂直扰动与冻结 NTK

在显式分析各个普适类之前，先注意冻结 NTK 递推 (9.6) 具有形式解

$$\Theta^{(\ell)} = \sum_{\ell'=1}^{\ell} \left\{ \left[\lambda_b^{(\ell')} + \lambda_W^{(\ell')} g^{(\ell'-1)} \right] \left[\prod_{\ell''=\ell'}^{\ell-1} \chi_{\perp}^{(\ell'')} \right] \right\}. \quad (9.28)$$

换句话说，这个解包含对先前所有层 $1, \dots, \ell$ 的求和，且求和中的每一项都包含一个加性贡献 $\lambda_b^{(\ell')} + \lambda_W^{(\ell')} g^{(\ell'-1)}$ 。随后，这一贡献与直至第 $(\ell-1)$ 层的垂直易感率递归相乘，产生总乘性因子 $\prod_{\ell''=\ell'}^{\ell-1} \chi_{\perp}^{(\ell'')}$ 。为避免这种因子通常引起的指数行为，必须令 $\chi_{\perp} = 1$ 。

把这一洞见同 §5.1 中对核递推所作的一般临界性分析联系起来，很有启发性。在那里，我们先考察单输入核，并令 $\chi_{\parallel} = 1$ ，以避免网络输出的指数行为。随后考察双输入核，分析非对角垂直扰动 $\delta\delta K_{[2]}^{(\ell)}$ 如何流动。关闭奇扰动 $\delta K_{[1]}^{(\ell)}$ 后，简要检查垂直递推 (5.48)

$$\delta\delta K_{[2]}^{(\ell+1)} = \chi_{\perp}^{(\ell)} \delta\delta K_{[2]}^{(\ell)}, \quad (9.29)$$

便要求施加临界性条件 $\chi_{\perp} = 1$ ，以便相邻输入之间的差异在网络中传播时得到保留。当时我们推测，从数据中学习时，这一条件有助于比较相邻输入。的确，冻结 NTK 的形式解 (9.28) 中出现的同一乘性因子，

$$\prod_{\ell''=\ell'}^{\ell-1} \chi_{\perp}^{(\ell'')} = \frac{\delta\delta K_{[2]}^{(\ell)}}{\delta\delta K_{[2]}^{(\ell')}}, \quad (9.30)$$

也出现在 $\delta\delta K_{[2]}^{(\ell)}$ 的形式解中。因此，借助两个形式解 (9.28) 与 (9.30)，我们形式化了保留 $\delta\delta K_{[2]}^{(\ell)}$ 数据与从数据中学习之间的联系。

形式性问题处理完毕，现在来分析两个卓越的普适类：尺度不变普适类与 $K^* = 0$ 普适类。

9.2 尺度不变普适类

提醒一下，尺度不变普适类的典型成员是 ReLU 与 linear 激活函数。对这个普适类中的一般激活函数，

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0, \end{cases} \quad (9.31)$$

回顾 §5.2，辅助函数与易感率求值为

$$g^{(\ell)} = A_2 K^{(\ell)}, \quad (9.32)$$

$$h^{(\ell)} = 0, \quad (9.33)$$

$$\chi_{\parallel}^{(\ell)} = \chi, \quad (9.34)$$

$$\chi_{\perp}^{(\ell)} = \chi, \quad (9.35)$$

其中 $\chi \equiv C_W A_2$. 把 (9.31) 代入并执行积分, 同样可以轻易算出另外三个所需的高斯期望,

$$\langle \sigma(z) \sigma(z) \sigma(z) \sigma(z) \rangle_{K^{(\ell)}} = 3A_4 (K^{(\ell)})^2, \quad (9.36)$$

$$\langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} = A_4 K^{(\ell)}, \quad (9.37)$$

$$\langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} = A_4. \quad (9.38)$$

这里以及刚才还使用了我们先前对这些积分中自然出现的常数所作的定义:

$$A_2 \equiv \frac{a_+^2 + a_-^2}{2}, \quad A_4 \equiv \frac{a_+^4 + a_-^4}{2}. \quad (9.39)$$

这些回顾提醒我们这个普适类的一个主要特征: 两个易感率都与核无关, 并且在所有层上保持常数. 因此, 只要把初始化超参数设为

$$C_b = 0, \quad C_W = \frac{1}{A_2}. \quad (9.40)$$

就很容易满足尺度不变普适类的临界性. 在这一调节下, 两个易感率都成为单位值 $\chi = 1$, 而核的不动点值由输入通过表达式 (5.66) 给出,

$$K^* \equiv \frac{1}{A_2} \left(\frac{1}{n_0} \sum_{j=1}^{n_0} x_j^2 \right), \quad (9.41)$$

临界处的四点顶角则由 (5.120) 给出,

$$V^{(\ell)} = (\ell - 1) \left(\frac{3A_4}{A_2^2} - 1 \right) (K^*)^2. \quad (9.42)$$

NTK 均值 (冻结 NTK)

考虑上述表达式后, 在临界性条件下, 单输入冻结 NTK 的递推 (9.6) 化简为

$$\Theta^{(\ell+1)} = \Theta^{(\ell)} + \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} A_2 K^*, \quad (9.43)$$

给定一组偏置与权重学习率后, 结合初始条件 (9.7), 很容易求解这个递推.

例如, 假设学习率与层无关, 即 $\lambda_b^{(\ell)} = \lambda_b$ 且 $\lambda_W^{(\ell)} = \lambda_W$, 便得到

$$\Theta^{(\ell)} = (\lambda_b + \lambda_W A_2 K^*) \ell. \quad (9.44)$$

在这些均匀学习率下, 尺度不变普适类的冻结 NTK 随深度线性增长. 由于 NTK 涉及对先前所有层的求和 (9.28), 线性增长意味着这些贡献在各层之间是均匀的; 这与非临界情形形成对比, 在后一情形中, 深度网络不同层的贡献会呈指数差异, 形式解 (9.28) 清楚地表明了这一点. 最后, 与拟设 (9.22) 比较可知, 冻结 NTK 的临界指数为 $p_\Theta = -1$. 我们将在 §9.4 中进一步解释所有这些要点.

NTK 方差与 NTK-预激活交叉相关 (受扰 NTK)

现在来计算有限宽度递推 (9.13)–(9.16), 以求得 NTK 方差与 NTK-预激活交叉相关.¹⁵⁰ 首先, 代入辅助函数 $g^{(\ell)} = A_2 K^{(\ell)}$ (9.32) 与 $h^{(\ell)} = 0$ (9.33), 并使用另外三个包含 A_4 的高斯期望公式 (9.36)–(9.38), 便可先化简这些递推. 随后选取 $C_W = 1/A_2$, 把初始化超参数调至临界性 (9.40); 这会令两个易感率都成为单位值 $\chi_{\parallel}^{(\ell)} = \chi_{\perp}^{(\ell)} = 1$, 并使核固定为 $K^{(\ell)} = K^*$. 经过这些操作, 得到

$$D^{(\ell+1)} = D^{(\ell)} + \lambda_W A_2 \left[\left(\frac{3A_4}{A_2^2} - 1 \right) (K^*)^2 + V^{(\ell)} \right] + \left(\frac{A_4}{A_2^2} - 1 \right) K^* \Theta^{(\ell)}, \quad (9.45)$$

$$F^{(\ell+1)} = F^{(\ell)} + \frac{A_4}{A_2^2} K^* \Theta^{(\ell)}, \quad (9.46)$$

$$B^{(\ell+1)} = B^{(\ell)} + \frac{A_4}{A_2^2} (\Theta^{(\ell)})^2, \quad (9.47)$$

$$A^{(\ell+1)} = A^{(\ell)} + (\lambda_W A_2)^2 \left[\left(\frac{3A_4}{A_2^2} - 1 \right) (K^*)^2 + V^{(\ell)} \right] + 2\lambda_W A_2 \left(\frac{A_4}{A_2^2} - 1 \right) K^* \Theta^{(\ell)} + 2\lambda_W A_2 D^{(\ell)} + \left(\frac{A_4}{A_2^2} - 1 \right) (\Theta^{(\ell)})^2. \quad (9.48)$$

注意, 与刚才求解 NTK 均值时一样, 这里也假设学习率与层无关.

接着, 代入 $V^{(\ell)}$ 的解 (9.42) 与 $\Theta^{(\ell)}$ 的解 (9.44), 便可轻易求解 $D^{(\ell)}$ 、 $F^{(\ell)}$ 和 $B^{(\ell)}$ 的递推. 随后利用所得的 $D^{(\ell)}$ 解, 还可以求解 $A^{(\ell)}$ 的递推. 合在一起, 得到以下各解:

$$D^{(\ell)} = \frac{\ell(\ell-1)}{2} \left[\lambda_b \left(\frac{A_4}{A_2^2} - 1 \right) K^* + \lambda_W A_2 \left(\frac{4A_4}{A_2^2} - 2 \right) (K^*)^2 \right], \quad (9.49)$$

$$F^{(\ell)} = \frac{\ell(\ell-1)}{2} \left[\frac{A_4}{A_2^2} (\lambda_b + \lambda_W A_2 K^*) K^* \right], \quad (9.50)$$

$$B^{(\ell)} = \frac{\ell(\ell-1)(2\ell-1)}{6} \left(\frac{A_4}{A_2^2} \right) (\lambda_b + \lambda_W A_2 K^*)^2, \quad (9.51)$$

$$A^{(\ell)} = \frac{\ell^3}{3} \left[\left(\frac{A_4}{A_2^2} - 1 \right) \lambda_b^2 + 3 \left(\frac{A_4}{A_2^2} - 1 \right) \lambda_b \lambda_W A_2 K^* + (5A_4 - 3A_2^2) \lambda_W^2 (K^*)^2 \right] + \dots, \quad (9.52)$$

其中, 对 $A^{(\ell)}$ 只保留了大 ℓ 下的领先贡献.

由这四个解可以读出尺度不变普适类的另外四个临界指数:

$$p_D = -2, \quad p_F = -2, \quad p_B = -3, \quad p_A = -3, \quad (9.53)$$

它们分别对应于 $D^{(\ell)}$ 和 $F^{(\ell)}$ 的二次增长, 以及 $B^{(\ell)}$ 和 $A^{(\ell)}$ 的三次增长. 再结合核的 $p_0 = 0$ 和冻结 NTK 的 $p_{\Theta} = -1$, 便得到此前宣告的、归一化量 (9.23) 与 (9.24) 所遵循的 ℓ/n 缩放 (9.27).

¹⁵⁰ 也可以选择分别计算 $D^{(\ell)}$ 与 $A^{(\ell)}$ 的 (9.20) 和 (9.21); 难度大致相当, 而且无论采用哪条路径, 显然都会得到同一个解.

9.3 $K^* = 0$ 普适类

提醒一下，这一普适类的两个重要成员是 $\tanh$ 与 $\sin$. 更一般地， $K^* = 0$ 普适类包含任何其对应核在 $K^* = 0$ 处具有非平凡不动点的激活函数.

具体而言，回顾 §5.3.3，我们用下列记号表示激活函数的 Taylor 系数：

$$\sigma(z) = \sum_{p=0}^{\infty} \frac{\sigma_p}{p!} z^p. \quad (9.54)$$

通过分析单输入核递推，我们了解到，在 $K^* = 0$ 处存在非平凡不动点，当且仅当激活函数在原点取零值且斜率非零 (5.89)，即

$$\sigma_0 = 0, \quad \sigma_1 \neq 0, \quad (9.55)$$

在此条件下，把初始化超参数调为 (5.90)

$$C_b = 0, \quad C_W = \frac{1}{\sigma_1^2}. \quad (9.56)$$

便可满足临界性条件. 下文始终假设偏置方差与重缩放权重方差已按照 (9.56) 调至临界性.

不同于尺度不变普适类， $K^* = 0$ 普适类的临界性分析是在 $K = 0$ 附近作微扰展开. 在这项分析中，我们按照 (5.83)–(5.85) 展开辅助函数 $g(K)$ 与两个易感率；现在结合 (9.55) 和 (9.56)，它们求值为

$$g(K) = \sigma_1^2 [K + a_1 K^2 + O(K^3)], \quad (9.57)$$

$$\chi_{\parallel}(K) = 1 + 2a_1 K + O(K^2), \quad (9.58)$$

$$\chi_{\perp}(K) = 1 + b_1 K + O(K^2), \quad (9.59)$$

其中还回顾了下列 Taylor 系数组合：

$$a_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \frac{3}{4} \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (9.60)$$

$$b_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \left(\frac{\sigma_2}{\sigma_1} \right)^2. \quad (9.61)$$

提醒一下，为得到这些表达式，我们先把其定义 (9.8)、(9.10) 与 (9.11) 关于 z 作 Taylor 展开，再把各个高斯期望级数计算到所需阶数. 沿用同一方法，可以计算辅助函数 $h(K)$ (9.9)，以及求解 NTK 递推所需的另外两个高斯期望：

$$h(K) = \frac{b_1}{2} + O(K^1), \quad (9.62)$$

$$\langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_K = \sigma_1^4 [K + O(K^2)], \quad (9.63)$$

$$\langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_K = \sigma_1^4 [1 + O(K^1)]. \quad (9.64)$$

回顾平行易感率刻画不动点附近核扰动的线性响应 (5.10)，由上式可见，临界处的平行易感率 (9.58) 在非平凡不动点 $K^* = 0$ 附近接近一。因此，我们曾为单输入核找到幂律形式的大 ℓ 渐近解 (5.94)，

$$K^{(\ell)} = K^* + \Delta K^{(\ell)} = \Delta K^{(\ell)} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + O\left(\frac{\log \ell}{\ell^2}\right), \quad (9.65)$$

它缓慢但确定地趋近 $K^* = 0$ 非平凡不动点，从而证明了深层渐近微扰方法的合理性。对于单输入四点顶角，我们先前得到 (5.127)

$$V^{(\ell)} = \left[\frac{2}{3a_1^2} \right] \frac{1}{\ell} + O\left(\frac{\log \ell}{\ell^2}\right), \quad (9.66)$$

而恰当归一化的量 (9.25) 具有 ℓ/n 缩放：

$$\frac{V^{(\ell)}}{n(K^{(\ell)})^2} = \left(\frac{2}{3}\right) \frac{\ell}{n} + O\left(\frac{\log(\ell)}{n}\right). \quad (9.67)$$

NTK 均值 (冻结 NTK)

从冻结 NTK 递推 (9.6) 的一般形式解 (9.28) 开始。注意，对 $K^* = 0$ 激活函数，把 $\delta\delta K_{[2]}^{(\ell)}$ 的大 ℓ 渐近解 (5.99) 代入后，乘性因子 (9.30) 取如下形式：

$$\prod_{\ell''=\ell'}^{\ell-1} \chi_{\perp}^{(\ell'')} = \frac{\delta\delta K_{[2]}^{(\ell)}}{\delta\delta K_{[2]}^{(\ell')}} = \left(\frac{\ell'}{\ell}\right)^{p_{\perp}} + \dots, \quad (9.68)$$

提醒一下，控制衰减的临界指数由 Taylor 系数组合给出，即 $p_{\perp} = b_1/a_1$ ；对 $\tanh$ 与 $\sin$ 激活函数，它等于 1。把这一乘性因子连同在渐近核 (9.65) 上求值的 $g(K)$ 展开 (9.57) 一起代回形式解 (9.28)，得到

$$\Theta^{(\ell)} = \sum_{\ell'=1}^{\ell} \left\{ \left[\lambda_b^{(\ell')} + \lambda_W^{(\ell')} \frac{\sigma_1^2}{(-a_1)} \left(\frac{1}{\ell'}\right) + \dots \right] \left[\left(\frac{\ell'}{\ell}\right)^{p_{\perp}} + \dots \right] \right\}. \quad (9.69)$$

这里，第一个方括号中的因子是从第 ℓ' 层获得的加性贡献，第二个方括号中的因子则是从第 ℓ' 层递归传播到第 ℓ 层产生的乘性贡献。

如果仍然天真地选择与层无关的学习率 $\lambda_b^{(\ell)} = \lambda_b$ 与 $\lambda_W^{(\ell)} = \lambda_W$ ，有效理论研究者可能会对解 (9.69) 的两个方面提出异议：

- 第一，注意第一个方括号中，偏置项的 ℓ' 依赖性与权重项相差一个 $\sim (1/\ell')$ 因子。这意味着，相对于偏置对 NTK 的贡献，权重的贡献会随深度减小。
- 第二，注意第二个方括号中的 $\sim (\ell')^{p_{\perp}}$ 行为；当 $p_{\perp} > 0$ 时，与较浅层相比，NTK 由较深层的贡献主导。回顾 NTK 控制可观测量的动力学 (8.3)，这又意味着训练动力学会受到输出层附近模型参数的强烈影响。

此外，实践工作者现在可能会疑惑，这些不自然的深度缩放是否也促成了深度学习界在经验上偏爱 ReLU 而非 $\tanh$. (更多讨论见 §9.4.)

尽管如此，可以通过消去层依赖性来纠正这一失衡：

$$\lambda_b^{(\ell)} \equiv \tilde{\lambda}_b \left(\frac{1}{\ell}\right)^{p_\perp}, \quad \lambda_W^{(\ell)} \equiv \tilde{\lambda}_W \left(\frac{1}{\ell}\right)^{p_\perp-1}, \quad (9.70)$$

其中 $\tilde{\lambda}_b$ 与 $\tilde{\lambda}_W$ 是与层无关的常数. 把这一拟设代入解 (9.69), 得到

$$\Theta^{(\ell)} = \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{1}{\ell}\right)^{p_\perp-1} + \dots, \quad (9.71)$$

它显式平衡了权重与偏置的贡献. 因此, 对 $K^* = 0$ 普适类, 冻结 NTK 的临界指数为

$$p_\Theta = p_\perp - 1. \quad (9.72)$$

尤其是, 对 $\tanh$ 与 $\sin$ 激活函数, 均有 $p_\Theta = 0$.

NTK 方差与 NTK-预激活交叉相关 (受扰 NTK)

现在终于来处理 $K^* = 0$ 普适类的受扰 NTK 统计. 为辅助临界处的计算, 利用核的渐近行为 (9.65), 并记录辅助函数 (9.57) 与 (9.62)、易感率 (9.58) 与 (9.59), 以及另外两个所需高斯期望 (9.63) 与 (9.64) 的领先大 ℓ 渐近式:

$$C_W g^{(\ell)} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \dots, \quad (9.73)$$

$$h^{(\ell)} = \frac{b_1}{2} + \dots, \quad (9.74)$$

$$\chi_{\parallel}^{(\ell)} = 1 - \frac{2}{\ell} + \dots, \quad (9.75)$$

$$\chi_{\perp}^{(\ell)} = 1 - \frac{p_\perp}{\ell} + \dots, \quad (9.76)$$

$$C_W^2 \langle \sigma(z) \sigma(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \dots, \quad (9.77)$$

$$C_W^2 \langle \sigma'(z) \sigma'(z) \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} = 1 + \dots. \quad (9.78)$$

此外, 下文假设偏置与权重学习率具有 (9.70) 所给的层依赖性; 其动机是让 NTK 的逐层贡献相等.

准备就绪后, 计算 $F^{(\ell)}$ 与 $B^{(\ell)}$ 的大 ℓ 渐近式十分直接. 把上述表达式和冻结 NTK 的渐近解 (9.71) 代入相应递推 (9.14) 与 (9.15), 得到

$$F^{(\ell+1)} = \left[1 - \frac{4}{\ell} + \dots \right] F^{(\ell)} + \left\{ \left[\frac{1}{(-a_1)} \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{1}{\ell}\right)^{p_\perp} + \dots \right\}, \quad (9.79)$$

$$B^{(\ell+1)} = \left[1 - \frac{2p_\perp}{\ell} + \dots \right] B^{(\ell)} + \left\{ \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell}\right)^{2p_\perp-2} + \dots \right\}. \quad (9.80)$$

代入缩放拟设 (9.22) 后, 它们在大 ℓ 下具有渐近解

$$F^{(\ell)} = \frac{1}{(5 - p_\perp)} \left[\frac{1}{(-a_1)} \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{1}{\ell} \right)^{p_\perp - 1} + \dots, \quad (9.81)$$

$$B^{(\ell)} = \frac{1}{3} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_\perp - 3} + \dots. \quad (9.82)$$

接着处理 $D^{(\ell)}$ 递推, 从稍微更紧凑的表达式 (9.20) 开始. 把表达式 (9.73)–(9.78)、学习率 (9.70), 以及四点顶角的渐近解 (9.66) 和冻结 NTK 的渐近解 (9.71) 代入, 得到递推

$$D^{(\ell+1)} = \left[1 - \frac{(p_\perp + 2)}{\ell} + \dots \right] D^{(\ell)} + \left\{ \left[\frac{2}{3(-a_1)} \right] \left[-p_\perp \tilde{\lambda}_b - (p_\perp - 1) \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{1}{\ell} \right)^{p_\perp} + \dots \right\}. \quad (9.83)$$

同样可以利用缩放拟设 (9.22) 轻易求解这一递推, 得到

$$D^{(\ell)} = \frac{-2}{9(-a_1)} \left[p_\perp \tilde{\lambda}_b + (p_\perp - 1) \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{1}{\ell} \right)^{p_\perp - 1} + \dots. \quad (9.84)$$

最后, 对 $A^{(\ell)}$ 的递推 (9.21), 采用如今已经熟悉的流程: 在书中前后翻页, 并代入大 ℓ 渐近表达式 (9.73)–(9.78)、学习率 (9.70)、四点顶角的渐近解 (9.66)、冻结 NTK 的渐近解 (9.71), 以及 $D^{(\ell)}$ 的渐近解 (9.84), 便得到

$$A^{(\ell+1)} = \left[1 - \frac{2p_\perp}{\ell} + \dots \right] A^{(\ell)} + \left\{ \frac{4}{9} \left[p_\perp \tilde{\lambda}_b + (p_\perp - 1) \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_\perp - 2} + \dots \right\}, \quad (9.85)$$

使用同一个大 ℓ 缩放拟设 (9.22) 可解得

$$A^{(\ell)} = \frac{4}{27} \left[p_\perp \tilde{\lambda}_b + (p_\perp - 1) \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_\perp - 3} + \dots. \quad (9.86)$$

至此, 我们完成了 $K^* = 0$ 普适类受扰 NTK 统计的计算.¹⁵¹

既然所有递推都已求解, 下面汇总并回顾临界指数. 由 (9.81) 与 (9.84) 得 $p_F = p_D = p_\perp - 1$, 由 (9.82) 与 (9.86) 得 $p_B = p_A = 2p_\perp - 3$. 再回顾核的 $p_0 = 1$ 与冻结 NTK 的 $p_\Theta = p_\perp - 1$, $K^* = 0$ 普适类的这些临界指数再次满足缩放律 (9.27), 即 (9.23) 与 (9.24) 中所定义归一化量的 ℓ/n 缩放. 再结合尺度不变情形的结果 (9.53), 可知拟设关系 (9.27) 的确跨越不同普适类持续成立, 因而构成缩放律.

总之, 我们发现, 无论激活函数为何, 由 NTK 方差与 NTK-预激活交叉相关衡量的 NTK-预激活联合分布领先有限宽度行为, 都具有相关的 ℓ/n 缩放; 按照有效理论的原理, 这是自然的.

¹⁵¹有趣的是, 对于 $\tanh$ 和 $\sin$ 这类 $p_\perp = 1$ 的激活函数, 单输入张量 $D^{(\ell)}$ 与 $A^{(\ell)}$ 的领先阶与权重学习率无关.

9.4 临界性、爆炸与消失问题，以及这些问题的消失

既然已经分析了深度网络的 NTK 统计，就让我们重新审视引入临界性的最初动机——爆炸与消失问题——来结束本章讨论。具体而言，我们终于要介绍梯度爆炸与消失问题，然后立即将其废除。¹⁵²

关于梯度爆炸与消失问题的传统观点

传统上，梯度爆炸与消失问题通过考察深度网络的损失梯度行为来体现。两次使用链式法则，损失关于第 ℓ 层模型参数 $\theta_\mu^{(\ell)}$ ——偏置 $\theta_\mu^{(\ell)} \equiv b_j^{(\ell)}$ 或权重 $\theta_\mu^{(\ell)} \equiv W_{jk}^{(\ell)}$ ——的导数取如下形式：

$$\frac{d\mathcal{L}_A}{d\theta_\mu^{(\ell)}} = \sum_{\alpha \in \mathcal{D}} \sum_{i_L=1}^{n_L} \sum_{i_\ell=1}^{n_\ell} \epsilon_{i_L;\alpha} \frac{dz_{i_L;\alpha}^{(L)}}{dz_{i_\ell;\alpha}^{(\ell)}} \frac{dz_{i_\ell;\alpha}^{(\ell)}}{d\theta_\mu^{(\ell)}}. \quad (9.87)$$

在这个梯度中，第一个因子是误差因子 (8.14)，

$$\epsilon_{i;\alpha} \equiv \frac{\partial \mathcal{L}_A}{\partial z_{i;\alpha}^{(L)}}, \quad (9.88)$$

最后一个因子是平凡因子 (8.11)，

$$\frac{dz_{i;\alpha}^{(\ell)}}{db_j^{(\ell)}} = \delta_{ij}, \quad \frac{dz_{i;\alpha}^{(\ell)}}{dW_{jk}^{(\ell)}} = \delta_{ij} \sigma_{k;\alpha}^{(\ell-1)}, \quad (9.89)$$

而中间的因子是链式法则因子，

$$\frac{dz_{i_L;\alpha}^{(L)}}{dz_{i_\ell;\alpha}^{(\ell)}} = \sum_{i_{\ell+1}, \dots, i_{L-1}} \frac{dz_{i_L;\alpha}^{(L)}}{dz_{i_{L-1};\alpha}^{(L-1)}} \cdots \frac{dz_{i_{\ell+1};\alpha}^{(\ell+1)}}{dz_{i_\ell;\alpha}^{(\ell)}} = \sum_{i_{\ell+1}, \dots, i_{L-1}} \prod_{\ell'=\ell}^{L-1} \left[W_{i_{\ell'+1} i_{\ell'}}^{(\ell'+1)} \sigma'_{i_{\ell'};\alpha}^{(\ell')} \right], \quad (9.90)$$

它可以通过迭代反向方程 (8.17) 推导；等价地，也可以结合 MLP 前向方程 (8.9) 反复使用链式法则。如果这段文字让读者自身产生了很大的误差因子，请向前翻回 §8.0，复习我们对误差反向传播算法的讨论。

关键在于，若不作任何精细调节，链式法则因子 (9.90) 中从第 ℓ 层到第 L 层的矩阵乘积通常会导致指数行为。即便网络深度适中，这也会使较浅层的参数极难获得行为良好的梯度，因而无法得到恰当训练：梯度消失意味着这些参数无法从数据与损失接收到训练信号；梯度爆炸则表示一种不稳定性，损失可能增大甚至发散。这就是**梯度爆炸与消失问题**。从某种意义上说，它是我们已经熟悉的、由前向迭代方程产生的核爆炸与消失问题的反向迭代对偶。¹⁵³

当然，要使训练稳定，不仅链式法则因子 (9.90) 必须行为良好，误差因子 (9.88) 与平凡因子 (9.89) 也必须如此。如下文所解释的，后两个因子与核爆炸与消失问题直接相关。不过我们也将看到，已经充分理解的临界性概念足以同时缓解这两类爆炸与消失问题。

¹⁵² 这个问题最早是在训练（如今已略显过时的）循环神经网络（RNN）的语境中被注意到的 [58, 59]。那还是神经网络仍被称作神经网络、尚未成为深度学习的年代；换言之，当时 MLP 还不够深，这个问题尚未显而易见。

¹⁵³ 如果愿意，可以通过考察深度线性网络来具体看到这种对偶性；对这类网络，权重乘积的统计可以完全按照 §3 中的方法精确算出。

关于梯度爆炸与消失问题的临界观点

关键地，回顾 §3.2 以及随后 §5.1 中对核爆炸与消失问题的讨论。在这些章节中，我们最初把临界性作为修复核 $K_{\alpha_1\alpha_2}^{(\ell)}$ 指数行为的手段。由于第 L 层核控制网络输出的典型值，而数据集的标签通常是 $O(1)$ 数，我们曾指出核爆炸或消失会给训练带来问题。如今已经了解了一些梯度下降，可以通过考察网络梯度 (9.87) 的所有组成因子，更直接地看到这种不稳定性的体现。

首先来看误差因子 (9.88) 如何与核爆炸问题相联系。例如，MSE 损失 (7.2) 的误差因子由 (7.15) 给出：

$$\epsilon_{i;\alpha} = z_{i;\alpha}^{(L)} - y_{i;\alpha}. \quad (9.91)$$

显然，若核发生爆炸，典型输出以及误差因子的典型值也会爆炸。¹⁵⁴ 为确保不发生这种情况，必须令 $\chi_{\parallel}(K^*) \leq 1$ 。

其次，注意权重的平凡因子 (9.89) 与激活成正比。对尺度不变普适类或 $K^* = 0$ 普适类中的激活函数，如果核以及相应的典型预激活呈指数小，激活以及相应的平凡因子也会受到指数抑制。随后，网络较深层的权重只能获得指数小的更新，因而难以训练。所以，为避免核消失问题，要求 $\chi_{\parallel}(K^*) \geq 1$ 。¹⁵⁵

结合这两点可见，核爆炸与消失问题直接表现为梯度爆炸与消失问题的一个子问题；同时也可看出，施加于平行易感率的临界性条件 $\chi_{\parallel}(K^*) = 1$ 如何缓解这一问题。

还可以通过考察平凡因子在 NTK 中的体现，进一步说明其消失。考虑冻结 NTK 的形式解 (9.28) 并回顾原始定义 (8.7)，可以追踪权重导数的贡献，它产生加性项 $\lambda_W^{(\ell')} g^{(\ell'-1)}$ 。对指数消失的核，该因子受到指数抑制：

$$\lambda_W^{(\ell')} g^{(\ell'-1)} \propto K^{(\ell'-1)} \lll 1, \quad (9.92)$$

因为对尺度不变普适类， $g(K) = A_2 K$ (9.32)；对 $K^* = 0$ 普适类， $g(K) = \sigma_1^2 K + O(K^2)$ (9.57)。这以另一种方式表明，较深层权重不再对训练动力学作出贡献；特别地，这也意味着这些权重对其他参数更新的影响极小。

类似地，链式法则因子 (9.90) 也编码在 NTK 的乘性因子 $\prod_{\ell''=\ell'}^{\ell-1} \chi_{\perp}^{(\ell'')}$ (9.30) 中。事实上，这个因子一直秘密潜藏于 NTK 前向方程 (8.8) 或 (8.12) 之中，充当递归项的系数。为揭开这个秘密，注意在无限宽度极限下链式法则因子的期望发生因子化；由 (8.8) 或 (8.12) 可见

$$\mathbb{E} \left[\sum_{j_1, j_2} \frac{dz_i^{(\ell+1)}}{dz_{j_1}^{(\ell)}} \frac{dz_i^{(\ell+1)}}{dz_{j_2}^{(\ell)}} \right] = \mathbb{E} \left[\sum_{j_1, j_2} W_{ij_1}^{(\ell+1)} W_{ij_2}^{(\ell+1)} \sigma'_{j_1}(\ell) \sigma'_{j_2}(\ell) \right] = C_W \langle \sigma'(z) \sigma'(z) \rangle_{K^{(\ell)}} = \chi_{\perp}^{(\ell)}, \quad (9.93)$$

从而显式建立了这种联系。

正如在 §9.1 的“形式性：垂直扰动与冻结 NTK”标题下所讨论的，为使训练平均而言行为良好，必须控制这些乘性的链式法则因子。特别地，若 $\chi_{\perp}(K^*) > 1$ ，较深层

¹⁵⁴稍稍超前一步，敏锐的读者可能会问，这对交叉熵损失是否重要，因为对这种损失，即使网络输出爆炸，误差因子仍会保持 $O(1)$ 。然而在这种情形中，模型会对其预测产生（指数级的）过度自信，而这种归纳偏置难以通过训练纠正。

¹⁵⁵顺带一提，对尺度不变普适类，同一逻辑还为避免核爆炸问题提供了额外理由。由于尺度不变激活函数不会饱和，若 $\chi_{\parallel}(K^*) > 1$ ，激活以及平凡因子便会爆炸。

NTK 会呈指数爆炸，训练动力学将不稳定，并可能导致损失增大。若 $\chi_{\perp}(K^*) < 1$ ，较浅层偏置与权重对较深层 NTK 的贡献则会呈指数衰减。这既意味着这些参数难以通过梯度下降更新而移动，也意味着它们难以影响较深层参数的演化。

总而言之，链式法则因子对梯度爆炸与消失问题的贡献，直接联系于 NTK 中呈指数增长或衰减的乘性因子；同时也可看出，施加于垂直易感率的临界性条件 $\chi_{\perp}(K^*) = 1$ 如何缓解这一问题。¹⁵⁶

学习率的等效原理

尽管两个临界性条件最初是通过考察核递推的行为推导出来的，我们刚才又通过直接分析梯度下降更新与 NTK 前向方程，重新得到了 $\chi_{\parallel}(K^*) = 1$ 和 $\chi_{\perp}(K^*) = 1$ 。其中的关键指导原则是，每一层对 NTK 的贡献不应呈指数差异。

不过，没有理由只停留在指数层面。事实上，还可以在多项式层面进一步要求：在训练中，任何一种模型参数和任何一层都不应支配其他参数或层。换言之，不仅要求不同层参数的贡献大致相等，还要求每一层中每个参数组对 NTK 的贡献在参数意义上相等。这给出了设定训练超参数，即偏置与权重学习率的**等效原理**。实际上，在走到本节的过程中，我们已经为每个普适类找到了满足这一等效原理的方法。

如在 §9.2 中回顾性地看到的，对尺度不变普适类中的激活函数，只要令偏置与权重学习率与层无关，就很容易满足等效原理：

$$\eta\lambda_b^{(\ell)} = \frac{\eta\tilde{\lambda}_b}{L}, \quad \frac{\eta\lambda_W^{(\ell)}}{n_{\ell-1}} = \frac{\eta\tilde{\lambda}_W}{Ln_{\ell-1}}. \quad (9.94)$$

这里还再次强调了权重学习率按前一层宽度重缩放，这一点已在 §8.0 中讨论多次。特别地，等效原理中“参数意义上相等的贡献”这一规定，应理解为要求恰当的深度和宽度缩放。此外，考虑 §8.0 中“有效理论中的缩放”标题下的讨论，注意我们还用网络总深度 L 重缩放学习率，以使输出层 NTK 为 $O(1)$ 。这既确保可在不同深度的模型之间自然比较重缩放学习率 $\eta\tilde{\lambda}_b$ 与 $\eta\tilde{\lambda}_W$ ，也确保任意梯度下降更新后，可观测量（例如损失）的变化得到恰当缩放并保持 $O(1)$ 。

与此同时，对 $K^* = 0$ 普适类，我们在 §9.3 中回顾性地看到，等效原理要求

$$\eta\lambda_b^{(\ell)} = \eta\tilde{\lambda}_b \left(\frac{1}{\ell}\right)^{p_{\perp}} L^{p_{\perp}-1}, \quad \frac{\eta\lambda_W^{(\ell)}}{n_{\ell-1}} = \frac{\eta\tilde{\lambda}_W}{n_{\ell-1}} \left(\frac{L}{\ell}\right)^{p_{\perp}-1}, \quad (9.95)$$

这里回顾了偏置与权重学习率采用不同深度缩放 (9.70) 的讨论；这样可以确保各参数

¹⁵⁶既然已经说明临界性为何是梯度爆炸与消失问题的完整解决方案，下面来讨论传统方法的补救措施。

最早的启发式解法之一——最初在循环神经网络语境中讨论——是梯度裁剪 [60]，即每当梯度范数超过某个阈值时就将其减小。根据上述讨论应当已经清楚，这种临时拼凑、造成扭曲且难以调节的启发式方法，对于处于临界性的网络完全没有必要，甚至可能具有破坏性。

第二种启发式解法是采用 ReLU。回顾 $\tanh$ 与 sigmoid 等激活函数在 $|z| \rightarrow \infty$ 时会发生饱和，这意味着激活的导数在饱和时消失，即 $\sigma'(z) = 0$ 。由 (9.90) 的右端很容易看出，这种饱和自然导致梯度消失。实践者采用 ReLU 而非 $\tanh$ 等饱和激活函数，部分正是出于这一背景（例如见 [19]）。不过，在更深入也更临界的理解下，我们现在认识到，只要某个激活函数允许临界初始化超参数，临界性就足以缓解其梯度消失问题；即使 $\tanh$ 这类饱和函数也不例外。

组与各层对渐近冻结 NTK 解 (9.71) 的贡献均匀.¹⁵⁷ 特别地，对 $\tanh$ 与 $\sin$ 这类光滑奇激活函数，垂直扰动的临界指数为 $p_{\perp} = 1$ ，因而有更简单的方案：

$$\eta\lambda_b^{(\ell)} = \frac{\eta\tilde{\lambda}_b}{\ell}, \quad \frac{\eta\lambda_W^{(\ell)}}{n_{\ell-1}} = \frac{\eta\tilde{\lambda}_W}{n_{\ell-1}}. \quad (9.96)$$

由此进一步令人怀疑，实践中偏爱 ReLU 而非 $\tanh$ ，是否至少部分因为 ReLU 的学习率天然与 ℓ 无关 (9.94)，而 $\tanh$ 的学习率需要非平凡的 ℓ 重缩放 (9.96).

最后，尽管 $O(1)$ 训练超参数 $\eta\tilde{\lambda}_b$ 与 $\eta\tilde{\lambda}_W$ 的最优值必然依赖具体任务，我们预计，等效原理规定的层 ℓ 、深度 L 与宽度 $n_{\ell-1}$ 缩放，在宽度 n_{ℓ} 与深度 L 不同的各种网络架构之间产生的变化最小.

¹⁵⁷ 请勿混淆这些 ℓ 重缩放与 L 重缩放. 前者用 ℓ 因子修正给定第 ℓ 层的学习率，后者则用网络总深度 L 修正网络中任意一层的学习率.

此外，结合刚才对核爆炸与消失问题的临界讨论，应当看到，偏置与权重学习率之间这种相对 ℓ 缩放正是核消失问题的多项式版本：等效原理确保较深层权重获得多项式意义上不消失的梯度，同时对其他参数的训练动力学作出多项式意义上相等的贡献.

第 10 章

核学习

我反对把无穷量当作实际实体来使用；数学中绝不允许这样做。无穷只是一种说法....

Carl Friedrich Gauss [61].

既然我们已经基本了解了关于预激活量以及 NTK 的初始化分布所能了解的一切，终于该用梯度来学习了！

本章将分析通过梯度下降优化训练无限宽度神经网络。当然，无限宽度网络实际上只是一种说法，我们无法在实践中真正实例化它。不过，正如先前的有限宽度分析所表明的，只要深宽比足够小，它们仍可作为实际实体的有用模型。

因此，分析这类网络有两个重要理由。第一，这一极限能告诉我们各种超参数应如何正确缩放与调节；此前已经看到，我们的临界性分析总是从无限宽度出发。第二，由于有限宽度分析是关于 $1/n$ 的微扰展开，理解无限宽度极限乃是我们将在 §11 与 §∞ 中理解更现实的有限宽度网络如何学习的先决条件。记住这些说明，下面先预览无限宽度下基于梯度的学习分析。

正如一个新生的生物神经网络以一小步开启旅程，刚刚初始化的人工神经网络也一样。在 §10.1 中，我们将迈出这样的一步，并看到无限宽度网络的梯度下降训练可由冻结 NTK 简单描述，而网络输出的变化可以相容地截断到全局学习率的一阶。这种简单性首先让我们看到网络的各输出分量彼此独立地移动 (§10.1.1)，继而发现隐藏层中不存在表征学习 (§10.1.2)。此时，你也许会产生一种诡异的似曾相识感，因为对于通过精确贝叶斯推断学习的无限宽度网络，我们已在 §6.3 中发现了完全相同的局限。

一小步之后便是一次巨大飞跃。在 §10.2 中，我们将作一次大的参数更新，得到完全训练的无限宽度网络的闭式解。对这类网络而言，该解会记住整个训练集；我们将说明，无论通过一次 Newton 步 (§10.2.1) 还是多步（随机）梯度下降 (§10.2.2) 到达它，该解都相同，而且不依赖所用损失的具体形式 (§10.2.3)。

事实上，在 §10.2.4 中将看到，一个特定的完全训练无限宽度网络在未见测试输入上的预测，完全由初始网络输出、冻结 NTK 和训练集内容确定。为分析这一点，我们计算相应系综的统计量，辨认出平均（神经正切）核预测以及该预测在不同实现间的协方差。回顾 §6.2.1 中关于贝叶斯模型拟合近似方法的讨论，现在便能更精确地说明基于梯度的学习与最大似然估计之间的联系：我们将讨论完全训练无限宽度网络上的分布在何种意义下构成广义后验分布。

在 §10.3 中，我们将检验这些完全训练无限宽度网络的预测。这里将引入衡量训练成功程度的定量指标——泛化误差，并把它分解为偏差项和方差项。前者比较系综在测

试输入上的平均预测与测试集给出的真实函数值，后者则度量这一预测在系综中不同完全训练网络实现之间的涨落。

自然地，偏差项与方差项之间存在权衡，对应于我们希望系综中的网络既灵活又有信心。在 §10.3.1 中，我们将显式算出测试输入接近某个训练样本时的泛化误差，并看到如何通过平衡这种权衡给出超参数调节方案：依照临界性原理调节初始化超参数，依照学习率等效原理调节训练超参数。

在 §10.3.2 中，我们会把分析扩展到测试输入接近两个训练样本的情形。这将帮助我们理解完全训练的网络如何插值与外推，并让我们一般性地评论激活函数对网络输出所诱导的归纳偏置。特别地，我们将看到非线性激活函数如何围绕两个训练样本作非线性插值或外推。

最后，在 §10.4 中，我们将稍稍后退一步，把无限宽度网络的讨论置于更广阔背景下。具体而言，我们会介绍传统机器学习中最简单的模型之一——线性模型，并解释它与另一类传统算法——核方法——之间的关系。由此将看到，无限宽度 MLP 本质上只是基于随机特征的线性模型；对偶地，我们也能把无限宽度贝叶斯核和冻结神经正切核都与这种更传统的核概念对应起来。

讨论完这类核方法的局限后，你将彻底理解为什么必须超越无限宽度极限，使我们的有效理论能够完整纳入实用深度学习模型中一些更令人兴奋的性质。

10.1 一小步

现在，让我们迈出通往损失最小值之旅的第一步。首先考察初始化后 $t = 0$ 时第一步中预激活量如何变化。

回顾任意神经网络可观测量 $\mathcal{O}(z^{(\ell)})$ 的演化均由 NTK 通过更新方程 (8.3) 控制，于是对第 ℓ 层预激活量有：

$$\begin{aligned} \vec{d}z_{i;\delta}^{(\ell)} &\equiv z_{i;\delta}^{(\ell)}(t=1) - z_{i;\delta}^{(\ell)}(t=0) \\ &= -\eta \sum_{j=1}^{n_\ell} \sum_{\tilde{\alpha} \in \mathcal{A}} \frac{d\mathcal{L}_{\mathcal{A}}}{dz_{j;\tilde{\alpha}}^{(\ell)}} \hat{H}_{ij;\tilde{\alpha}\delta}^{(\ell)} + O(\eta^2). \end{aligned} \quad (10.1)$$

这里，第 ℓ 层 NTK $\hat{H}_{ij;\tilde{\alpha}\delta}^{(\ell)}$ 与因子 $d\mathcal{L}_{\mathcal{A}}/dz_{j;\tilde{\alpha}}^{(\ell)}$ 都在初始化时取值；从现在起，若某个量在初始化 $t = 0$ 时取值，我们将省略它对步数 t 的显式依赖，除非为了清楚而需要特别强调。此后，我们用前缀 $\vec{d}$ 表示梯度下降第一步之后某个量的更新。

此外，在写出 (10.1) 时，我们重新启用了带波浪号的 alpha 样本指标记号，表示训练集中的输入 $\tilde{\alpha} \in \mathcal{A}$ ；很快还会重新启用带点的 beta，表示测试集中的输入 $\dot{\beta} \in \mathcal{B}$ ；和以前一样，不带修饰的 delta 表示任一集合中的一般输入： $\delta \in \mathcal{D} = \mathcal{A} \cup \mathcal{B}$ 。因而，说得完全明确些，更新 (10.1) 给出了第一次梯度下降训练步骤之后，在测试集或训练集样本上求值的第 ℓ 层预激活量的变化。

现在专门考察无限宽度极限。回顾在这一极限下，NTK 会自平均，所以参数的任意特定实现所对应的 NTK 都等于无限宽度 NTK 均值，也就是我们一直所称的冻结

NTK: $\hat{H}_{ij;\tilde{\alpha}\delta}^{(\ell)} = \delta_{ij}\Theta_{\tilde{\alpha}\delta}^{(\ell)} + O(1/n)$. 考虑到这一点, 无限宽度下的更新方程化简为

$$\dot{z}_{i;\delta}^{(\ell)} = -\eta \sum_{\tilde{\alpha} \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}}^{(\ell)} \frac{d\mathcal{L}_{\mathcal{A}}}{dz_{i;\tilde{\alpha}}^{(\ell)}} + O\left(\frac{1}{n}\right). \quad (10.2)$$

这里, 更新不会混合神经元指标, 因为 NTK 均值在这些指标上是对角的; 而冻结 NTK 中若出现非对角项, 则意味着一个训练样本的信息会影响另一个训练样本的更新. 重要的是, 我们有意截去了 (10.1) 中的 $+O(\eta^2)$ 部分, 其中包含对全局学习率 η 作级数展开时更新的高阶修正; 在 §11 中, 我们会显式分析这些 $O(\eta^2)$ 项, 并说明它们受到 $1/n$ 的抑制. 因此, 在严格无限宽度极限下, 它们恒等于零, 使线性截断成为精确结果.

本节将考察这种无限宽度小步更新对于 $\ell = L$ 时网络输出 (§10.1.1) 以及 $\ell = L-1$ 时最后隐藏层预激活量 (§10.1.2) 意味着什么.¹⁵⁸ 这些分析将大体平行于 §6.3.2 与 §6.3.3; 在那里, 我们考察了通过精确贝叶斯推断更新的无限宽度网络的后验分布.

10.1.1 无连线

专门取网络输出 $z_{i;\delta}^{(L)}$, 更新 (10.2) 便成为

$$\dot{z}_{i;\delta}^{(L)} = -\eta \sum_{\tilde{\alpha} \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}}^{(L)} \epsilon_{i;\tilde{\alpha}}, \quad (10.3)$$

其中, 我们回顾由 (7.16) 定义、如今已十分熟悉的误差因子:

$$\epsilon_{i;\tilde{\alpha}} \equiv \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}}^{(L)}}. \quad (10.4)$$

我们将在 §10.2 及后续各节中深入分析这一网络输出更新. 这里先只指出, 第 i 个特征的更新 $\dot{z}_{i;\delta}^{(L)}(t=1)$ 仅依赖误差因子的第 i 个分量 $\epsilon_{i;\tilde{\alpha}}$. 这对应于我们在 §6.3.2 中对无限宽度下精确贝叶斯推断观察到的网络输出无连线现象.

更具体地说, 对于 MSE 损失 (7.2),

$$\mathcal{L}_{\mathcal{A}} \equiv \frac{1}{2} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha} \in \mathcal{A}} \left(z_{i;\tilde{\alpha}}^{(L)} - y_{i;\tilde{\alpha}} \right)^2, \quad (10.5)$$

误差因子就是真实输出与初始输出之差, $\epsilon_{i;\tilde{\alpha}} = z_{i;\tilde{\alpha}}^{(L)} - y_{i;\tilde{\alpha}}$. 因而可以看到, 所有输出分量都彼此独立地移动, 各分量之间的相关性无法被学习.¹⁵⁹ 此外, 由于 (10.3) 是描述系综中任意特定网络更新的随机方程, 对于训练一步后的无限宽度网络的任意特定实现, 也都不存在连线.

¹⁵⁸ 读完下一节后应该很清楚, 这里的结果即使在训练结束、损失达到最小值时也成立. 我们现在就指出这一点, 是为了预先回应如下形式的潜在异议: “是否会存在某个步数 t , 使得量 $\eta t/n$ 为一阶?”

¹⁵⁹ 再举一个例子, 可以取形如 $\mathcal{L}_{\mathcal{A}} = -\sum_{j,\tilde{\alpha}} p_{j;\tilde{\alpha}} \log(q_{j;\tilde{\alpha}})$ 的交叉熵损失; 不妨向后翻到 (10.36). 此时有一个目标分布 $p_{i;\tilde{\alpha}}$, 而我们希望拟合网络输出的 softmax 分布——参见 (6.11)—— $q_{i;\tilde{\alpha}} \equiv \exp(z_{i;\tilde{\alpha}}^{(L)}) / [\sum_k \exp(z_{k;\tilde{\alpha}}^{(L)})]$. 注意到 $\partial q_{j;\tilde{\alpha}} / \partial z_{i;\tilde{\alpha}}^{(L)} = (\delta_{ij} - q_{i;\tilde{\alpha}}) q_{j;\tilde{\alpha}}$ 后, 得到误差因子

$$\epsilon_{i;\tilde{\alpha}} = \sum_j \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial q_{j;\tilde{\alpha}}} \frac{\partial q_{j;\tilde{\alpha}}}{\partial z_{i;\tilde{\alpha}}^{(L)}} = -\sum_j \frac{p_{j;\tilde{\alpha}}}{q_{j;\tilde{\alpha}}} q_{j;\tilde{\alpha}} (\delta_{ij} - q_{i;\tilde{\alpha}}) = -p_{i;\tilde{\alpha}} + \left(\sum_j p_{j;\tilde{\alpha}} \right) q_{i;\tilde{\alpha}} = q_{i;\tilde{\alpha}} - p_{i;\tilde{\alpha}}. \quad (10.6)$$

因此, 在这种情形下同样可以看到, 误差因子 $\epsilon_{i;\tilde{\alpha}}$ 只依赖 softmax 分布的第 i 个分量, 输出分量之间不会生成任何相关性.

10.1.2 无表征学习

分析倒数第二层预激活量 $z_{i;\delta}^{(L-1)}$ 的更新需要多吃一些工作. 首先, 可以使用反向方程 (8.17), 计算更新方程 (10.2) 中损失的导数:

$$\frac{d\mathcal{L}_A}{dz_{j;\tilde{\alpha}}^{(L-1)}} = \sum_{i=1}^{n_L} \frac{\partial \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}}^{(L)}} \frac{dz_{i;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(L-1)}} = \sum_{i=1}^{n_L} \frac{\partial \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}}^{(L)}} W_{ij}^{(L)} \sigma'_{j;\tilde{\alpha}}^{(L-1)}. \quad (10.7)$$

将其代入 $\ell = L - 1$ 时的更新 (10.2), 便得到一个随机方程, 描述任意特定网络中最后隐藏层表征的变化:

$$\dot{dz}_{j;\delta}^{(L-1)} = -\eta \sum_{i=1}^{n_L} \sum_{\tilde{\alpha} \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}}^{(L-1)} \frac{\partial \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}}^{(L)}} W_{ij}^{(L)} \sigma'_{j;\tilde{\alpha}}^{(L-1)}. \quad (10.8)$$

为了继续推进, 必须分析这些更新的分布.

首先, 平均更新为

$$\mathbb{E} [\dot{dz}_{j;\delta}^{(L-1)}] = -\eta \sum_{i=1}^{n_L} \sum_{\tilde{\alpha} \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}}^{(L-1)} \mathbb{E} \left[\frac{\partial \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}}^{(L)}} W_{ij}^{(L)} \sigma'_{j;\tilde{\alpha}}^{(L-1)} \right]. \quad (10.9)$$

这个期望包含来自第 L 层的误差因子 $\partial \mathcal{L}_A / \partial z_{i;\tilde{\alpha}}^{(L)}$ 与来自第 $(L - 1)$ 层的激活函数导数 $\sigma'_{j;\tilde{\alpha}}^{(L-1)}$ 之间的层间相关, 此外还插入了权重 $W_{ij}^{(L)}$. 根据先前的经验, 我们知道这种层间期望受到 $1/n$ 因子的抑制, 在严格无限宽度极限下消失. 为格外谨慎起见, 下面显式计算该均值.

为此, 回顾层间相关的生成函数 (8.53), 并专门取倒数第二层 $\ell = L - 1$. (你大概会想翻回去提醒自己一下.) 由于此前尚未计算过插入单个权重的情形, 我们在此计算并记录它. 对源作一次 $\frac{d}{d\mathcal{J}_{ij}}$ 微分, 再把源设为零, 得到

$$\mathbb{E} [\mathcal{O}(z^{(L)}) W_{ij}^{(L)} \mathcal{Q}(z^{(L-1)})] = \frac{C_W^{(L)}}{n_{L-1}} \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i;\delta}^{(L)}} \right\rangle \right\rangle_{\hat{G}^{(L)}} \sigma_{j;\delta}^{(L-1)} \mathcal{Q}(z^{(L-1)}) \right]. \quad (10.10)$$

把这一公式应用于上面的更新表达式 (10.9), 得到

$$\begin{aligned} \mathbb{E} [\dot{dz}_{j;\delta}^{(L-1)}] &= -\eta \frac{C_W^{(L)}}{n_{L-1}} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}_1}^{(L-1)} \mathbb{E} \left[\left\langle \left\langle \frac{\partial^2 \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}_1}^{(L)} \partial z_{i;\tilde{\alpha}_2}^{(L)}} \right\rangle \right\rangle_{\hat{G}^{(L)}} \sigma_{j;\tilde{\alpha}_2}^{(L-1)} \sigma'_{j;\tilde{\alpha}_1}^{(L-1)} \right] \\ &= -\eta \frac{C_W^{(L)}}{n_{L-1}} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}_1}^{(L-1)} \sum_{i=1}^{n_L} \left\langle \left\langle \frac{\partial^2 \mathcal{L}_A}{\partial z_{i;\tilde{\alpha}_1}^{(L)} \partial z_{i;\tilde{\alpha}_2}^{(L)}} \right\rangle \right\rangle_{K^{(L)}} \langle \sigma'_{\tilde{\alpha}_1} \sigma_{\tilde{\alpha}_2} \rangle_{K^{(L-1)}} + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (10.11)$$

可见这一表达式显式受到 $1/n$ 的抑制. 因此, 对系综取平均后, 我们发现无限宽度极限下倒数第二层没有表征学习.

接下来考察更新 (10.8) 的方差:

$$\begin{aligned}
 & \mathbb{E} \left[\tilde{d}z_{j_1; \delta_1}^{(L-1)} \tilde{d}z_{j_2; \delta_2}^{(L-1)} \right] \\
 &= \eta^2 \sum_{i_1, i_2=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta_1 \tilde{\alpha}_1}^{(L-1)} \Theta_{\delta_2 \tilde{\alpha}_2}^{(L-1)} \mathbb{E} \left[\frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_1; \tilde{\alpha}_1}^{(L)}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_2; \tilde{\alpha}_2}^{(L)}} W_{i_1 j_1}^{(L)} W_{i_2 j_2}^{(L)} \sigma'_{j_1; \tilde{\alpha}_1}{}^{(L-1)} \sigma'_{j_2; \tilde{\alpha}_2}{}^{(L-1)} \right] \\
 &= \delta_{j_1 j_2} \eta^2 \frac{C_W^{(L)}}{n_{L-1}} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta_1 \tilde{\alpha}_1}^{(L-1)} \Theta_{\delta_2 \tilde{\alpha}_2}^{(L-1)} \sum_{i=1}^{n_L} \left\langle \left\langle \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_1; \tilde{\alpha}_1}^{(L)}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i_2; \tilde{\alpha}_2}^{(L)}} \right\rangle \right\rangle_{K^{(L)}} \langle \sigma'_{\tilde{\alpha}_1} \sigma'_{\tilde{\alpha}_2} \rangle_{K^{(L-1)}} + O\left(\frac{1}{n^2}\right).
 \end{aligned} \tag{10.12}$$

最后一步中, 我们应用了插入两个权重的层间相关公式 (8.55), 并取其领先贡献.¹⁶⁰ 由此可见, 更新的协方差

$$\text{Cov} \left[\tilde{d}z_{j_1; \delta_1}^{(L-1)}, \tilde{d}z_{j_2; \delta_2}^{(L-1)} \right] \equiv \mathbb{E} \left[\tilde{d}z_{j_1; \delta_1}^{(L-1)} \tilde{d}z_{j_2; \delta_2}^{(L-1)} \right] - \mathbb{E} \left[\tilde{d}z_{j_1; \delta_1}^{(L-1)} \right] \mathbb{E} \left[\tilde{d}z_{j_2; \delta_2}^{(L-1)} \right] = O\left(\frac{1}{n}\right), \tag{10.13}$$

显式受到 $1/n$ 的抑制, 在严格无限宽度极限下消失. 由于倒数第二层预激活量更新的分布具有消失的均值与协方差, 我们得出结论: 学习更新前后的分布相等. 与 §6.3.3 中精确贝叶斯推断的结果相呼应, 在无限宽度极限下, 基于梯度的学习不存在表征学习.¹⁶¹

10.2 巨大飞跃

这是机器的一小步, 却是 AI 的一次巨大飞跃.

Neil AI-Strong

上一节中, 我们通过迈出梯度下降的一小步, 开始理解无限宽度网络的训练. 当然, 我们真正想理解的是完全训练的网络在损失最小值处的行为. 自然地, 我们可以不断迈出许许多多小步, 直至网络完全训练; 实践中通常正是这样训练网络的.

不过, 在 §10.2.1 中, 我们首先会说明, 实际上只需一次理论上的梯度下降步骤, 就能完全训练无限宽度网络. 也就是说, 可以直接作一次巨大飞跃, 抵达损失最小值. 随后, 我们将在 §10.2.2 中解释, 通过这次巨大飞跃找到的理论最小值, 与实践中通过多步梯度下降、乃至使用学习率递减的随机梯度下降所找到的最小值相同. 这种等价性使巨大飞跃成为一种强有力的理论工具. 在 §10.2.3 中短暂插叙交叉熵损失之后, 最后会在 §10.2.4 中看到完全训练的无限宽度网络如何对先前未见的样本作预测, 不过这些测试集预测的详细分析要留到下一节.

10.2.1 Newton 方法

我们的第一个目标, 是找到一个使网络输出等于真实输出的单步更新,

$$z_{i; \tilde{\alpha}}^{(L)}(t=1) = y_{i; \tilde{\alpha}}, \tag{10.14}$$

¹⁶⁰注意, (8.55) 中第二项的阶为 $O(1/n^2)$, 因而是次领先的.

¹⁶¹如果愿意, 你也可以检验更新分布的高阶连通相关函数. 不过, 正如开始这些计算前已经指出的, 这类层间相关自然受到 $1/n$ 因子的抑制, 高阶连通相关函数也同样如此.

并要求它对训练集 $\tilde{\alpha} \in \mathcal{A}$ 中的所有样本 $x_{\tilde{\alpha}}$ 都成立. 这一条件将作为完全训练的定义; 容易看出, 对于前述任意损失函数, 它都会使训练损失达到最小. 回顾神经网络输出的梯度下降更新 (10.3) 并重排各项, 可见巨大飞跃更新必须满足

$$z_{i;\tilde{\alpha}_1}^{(L)} - y_{i;\tilde{\alpha}_1} = \eta \sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}_2}^{(L)}} \quad (10.15)$$

网络才能完全训练.

提醒一下, 我们的约定是: 不带显式步数参数的量均在初始化点 $t = 0$ 处取值; 特别地, 约束 (10.15) 完全由初始化时的量写成. 还要注意, $\tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$ 上的波浪号强调, 它是完整冻结 NTK 矩阵 $\Theta_{\delta_1 \delta_2}^{(L)}$ 的一个 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 维子矩阵, 只在训练集 $\mathcal{A}$ 中的输入对 $(x_{\tilde{\alpha}_1}, x_{\tilde{\alpha}_2})$ 上取值. 这一强调很快就会像先前在 §6 中那样发挥作用.

怎样才能满足巨大飞跃条件 (10.15)? 由于左边恰好是 MSE 损失 (10.5) 的误差因子, 我们先专门取 MSE 损失. 把 (10.5) 代入 $\mathcal{L}_{\mathcal{A}}$, 得到一个具体的待解方程:

$$z_{i;\tilde{\alpha}_1}^{(L)} - y_{i;\tilde{\alpha}_1} = \sum_{\tilde{\alpha}_2 \in \mathcal{A}} \eta \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \left(z_{i;\tilde{\alpha}_2}^{(L)} - y_{i;\tilde{\alpha}_2} \right). \quad (10.16)$$

然而, 对于一般神经网络, 冻结 NTK $\Theta_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$ 会有混合不同样本指标的非零非对角分量. 遗憾的是, 这意味着仅调节单个全局学习率 η , 不可能满足条件 (10.16).

换句话说, 问题在于全局学习率 η 是一个标量, 但为了消除冻结 NTK 对样本指标的混合, 这里需要它是张量. 为此, 必须进一步推广梯度下降. 在梯度下降算法 (7.11) 的第一次推广中——见标题张量梯度下降下的讨论——我们在参数空间上引入了学习率张量,

$$\eta \rightarrow \eta \lambda_{\mu\nu}, \quad (10.17)$$

它让我们能够调节每个模型参数分别如何参与其他参数的梯度下降更新, 并允许在参数空间的不同方向上迈出大小不等的步子. 学习率张量的影响被纳入 NTK 的定义, 进而支撑了 §7–§9 中的分析.¹⁶²

现在还需要把这一推广进一步扩展到样本指标:

$$\eta \lambda_{\mu\nu} \rightarrow \eta \lambda_{\mu\nu} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}, \quad (10.18)$$

这里引入了一个新的对称矩阵 $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 称为 **Newton 张量**. 它使我们也能在样本空间中迈出各向异性的步子. 具体而言, 把参数更新方程 (7.11) 扩展为

$$d\theta_{\mu} \equiv \theta_{\mu}(t=1) - \theta_{\mu}(t=0) = - \sum_{\nu, \tilde{\alpha}_1, \tilde{\alpha}_2, i} \eta \lambda_{\mu\nu} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} \frac{dz_{i;\tilde{\alpha}_1}^{(L)}}{d\theta_{\nu}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}_2}^{(L)}}, \quad (10.19)$$

¹⁶²最重要的是, 它允许偏置和权重的有效学习率以不同方式缩放; 我们在 §8.0、随后又在 §9.4 中看到, 这对于确保两组参数都得到恰当训练至关重要. 请记住, 即使一般地写作 $\lambda_{\mu\nu}$, 我们的学习率张量也受到限制, 不会混合来自不同层的参数.

并称之为**二阶更新**.¹⁶³ 把这一二阶更新代入网络输出的展开, 得到

$$\begin{aligned} z_{i;\delta_1}^{(L)}(t=1) &= z_{i;\delta_1}^{(L)} + \sum_{\mu} \frac{dz_{i;\delta_1}^{(L)}}{d\theta_{\mu}} d\theta_{\mu} + O\left(\frac{1}{n}\right) \\ &= z_{i;\delta_1}^{(L)} - \eta \sum_{\tilde{\alpha}_2, \tilde{\alpha}_3 \in \mathcal{A}} \Theta_{\delta_1 \tilde{\alpha}_2}^{(L)} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_3} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}_3}^{(L)}} + O\left(\frac{1}{n}\right). \end{aligned} \quad (10.20)$$

将此更新代入完全训练条件 (10.14), 并仍使用 MSE 损失, 得到一个新约束

$$z_{i;\tilde{\alpha}_1}^{(L)} - y_{i;\tilde{\alpha}_1} = \sum_{\tilde{\alpha}_2, \tilde{\alpha}_3 \in \mathcal{A}} \left(\eta \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_3} \right) \left(z_{i;\tilde{\alpha}_3}^{(L)} - y_{i;\tilde{\alpha}_3} \right). \quad (10.21)$$

稍后就会满足这一约束.

还可以从另一个角度看待新的二阶更新: 不修改优化算法, 而改用不同的损失, 也能得到相同的约束 (10.21). 考虑广义 MSE 损失

$$\mathcal{L}_{\mathcal{A}, \kappa}(\theta) = \frac{1}{2} \sum_{i=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} \left(z_{i;\tilde{\alpha}_1}^{(L)} - y_{i;\tilde{\alpha}_1} \right) \left(z_{i;\tilde{\alpha}_2}^{(L)} - y_{i;\tilde{\alpha}_2} \right), \quad (10.22)$$

这里, Newton 张量 $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 充当样本空间上的度量.¹⁶⁴ 对这一损失, 关于网络输出的导数——也就是误差因子——现在为

$$\frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{i;\tilde{\alpha}_2}^{(L)}} = \sum_{\tilde{\alpha}_3 \in \mathcal{A}} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_3} \left(z_{i;\tilde{\alpha}_3}^{(L)} - y_{i;\tilde{\alpha}_3} \right). \quad (10.23)$$

把这一误差因子代入完全训练条件 (10.15), 就会发现: 使用标准梯度下降更新与广义 MSE 损失 (10.22), 得到的约束 (10.21), 与刚才使用二阶更新 (10.19) 和标准 MSE 损失得到的约束相同. 这两种观点都是理解理论优化的有效方式; 正如 §10.2.2 中将更一般地解释的, 无论选择其中哪种算法与损失, 都会得到同一个完全训练的网络.

现在来求巨大飞跃约束 (10.21) 的解. 直接观察可知, 如果能把第一个括号中的项设为单位矩阵, 就可满足它:

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \eta \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{\tilde{\alpha}_1}^{\tilde{\alpha}_3}, \quad (10.24)$$

这可通过把全局学习率与 Newton 张量的乘积设为

$$\eta \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} = \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2}. \quad (10.25)$$

¹⁶³ 这一名称源于如下事实: 类似更新被用于定义纳入损失二阶导数信息的优化算法. 这类算法通常称为二阶方法. 很快我们会说明, 这种新算法同样可以使损失最小化 (实际上做得更好).

¹⁶⁴ 类似地, 也可以把学习率张量 $\lambda_{\mu\nu}$ 看作参数空间上的度量.

还要注意, 在这种解释下, 标准 MSE 损失就是采用欧氏度量 $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} \rightarrow \delta^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的广义 MSE 损失. 如果你熟悉广义相对论, 从某种意义上说, 这种写法更令人愉悦; 把 Newton 张量的样本指标升高后, 便可采用一条规则: 只有样本指标以一上一下成对出现时才求和. 类似地, 请注意在二阶更新 (10.19) 中插入 Newton 张量也遵循这一模式.

来保证. 这里, 右边的对象是 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 维子矩阵 $\tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}$ 的逆; 提醒一下, 这个子矩阵只在训练集 $\mathcal{A}$ 中的输入对 $(x_{\tilde{\alpha}_1}, x_{\tilde{\alpha}_2})$ 上取值, 并由方程

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{\Theta}_{\tilde{\alpha}_2 \tilde{\alpha}_3}^{(L)} = \delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1}. \quad (10.26)$$

定义. 与 §6.3 中对无限宽度贝叶斯推断所作的处理类似, 用波浪号修饰这些子矩阵, 有助于把它们与还涉及测试集 $\mathcal{B}$ 的子矩阵清楚区分开. 此外, 与此前对核及其逆所作的约定一样, 我们总以样本指标升高的对象表示 NTK 的逆.

采用特定选择 (10.25) 的算法称为 **Newton 方法** (这也超越因果时序地解释了为何把 $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 称为 *Newton 张量*)¹⁶⁵. 借助它, 可以直接写出一步完全训练网络的解:

$$\theta_{\mu}^* = \theta_{\mu}(t=0) - \sum_{\nu, \tilde{\alpha}_1, \tilde{\alpha}_2, i} \lambda_{\mu\nu} \frac{dz_{i; \tilde{\alpha}_1}^{(L)}}{d\theta_{\nu}} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \left(z_{i; \tilde{\alpha}_2}^{(L)} - y_{i; \tilde{\alpha}_2} \right). \quad (10.30)$$

特别地, 这恰好就是像 (7.7) 那样令损失梯度为零并求解最优参数所得的结果. 正如当时解释的, 只有在特殊情形下, 优化问题才存在这种直接而显式的解; 事实证明, 无限宽度恰好就是这种情形.¹⁶⁶

再把 Newton 方法更新代入网络输出展开 (10.20), 便得到一般输入 $\delta \in \mathcal{D}$ 上完全训练的网络输出:

$$z_{i; \delta}^{(L)}(t=1) = z_{i; \delta}^{(L)} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta \tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \left(z_{i; \tilde{\alpha}_2}^{(L)} - y_{i; \tilde{\alpha}_2} \right). \quad (10.31)$$

¹⁶⁵ Newton 方法是一种寻找函数零点的数值方法. 为简化叙述, 取单变量函数 $g(x)$, 并假设要寻找方程 $g(x_*) = 0$ 的解; 注意, 这等价于求导数为 $g(x)$ 的函数 $L(x)$ 的极值, 即 $L'(x) = g(x)$. Newton 方法要求从某个猜测 x_0 开始, 并按如下方式迭代:

$$x_{t+1} = x_t - \frac{g(x_t)}{g'(x_t)} = x_t - \frac{L'(x_t)}{L''(x_t)}. \quad (10.27)$$

这一算法基于线性近似 $g'(x_t) \approx [g(x_{t+1}) - g(x_t)]/(x_{t+1} - x_t)$, 然后令 $g(x_{t+1}) = 0$ 并求解. 一般来说, 需要迭代 (10.27) 若干步, 才能得到良好的近似解 x_* . 然而, 当函数是线性的, 即 $g(x) = a(x - x_*)$ 时, 有

$$x_1 = x_0 - \frac{a(x_0 - x_*)}{a} = x_*, \quad (10.28)$$

它对任意初始点 x_0 都成立. 因而 Newton 方法可以像巨大飞跃 (10.30) 那样, 只用一步就准确落在解上.

方程 (10.27) 的右边还给出另一种观点: Newton 方法就是使用“损失” $L(x)$ 的梯度下降, 并把学习率设为 $\eta_t = 1/L''(x_t)$. 为说明这为何是学习率的良好选择, 取一般学习率 $x_{t+1} = x_t - \eta_t L'(x_t)$, 并把更新后的损失 $L(x_{t+1})$ 关于 η_t 展开到二阶:

$$L(x_{t+1}) = L(x_t) - \eta_t L'(x_t) + \frac{\eta_t^2}{2} L'(x_t)^2 L''(x_t) + O(\eta_t^3). \quad (10.29)$$

优化学习率可见, 当 $\eta_t = 1/L''(x_t)$ 时, 右边的截断表达式达到最小. 特别地, 对于二次函数 $L(x) = a(x - x_*)^2/2$, 这一截断是精确的, Newton 方法同样能一步到达最小值. 这也说明了为什么基于 Newton 方法的优化算法属于二阶方法: 每次迭代都利用函数的二阶信息——二阶导数 $L''(x)$ ——设定局部最优学习率. 方程 (10.30) 与 (10.31) 所表示的巨大飞跃, 分别对参数优化与函数逼近作了完全相同的事情, 而且成功了.

¹⁶⁶稍后将在 §∞.2 中说明, 有限宽度下可以得到微扰解.

特别地，对训练集 $\mathcal{A}$ 中的样本，网络输出等于真实输出 $z_{i;\tilde{\alpha}}^{(L)}(t=1) = y_{i;\tilde{\alpha}}$ ，从而满足完全训练条件 (10.14)。换言之，网络完美地记住了整个训练集。¹⁶⁷ 因而，解 (10.30) 也会使任意损失 $\mathcal{L}_{\mathcal{A}}(\theta)$ 达到最小，只要该损失在网络输出等于真实输出 $z^{(L)}(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 时达到最小：

$$\theta_{\text{Newton}}^* = \arg \min_{\theta} \mathcal{L}_{\mathcal{A}}(\theta). \quad (10.32)$$

这意味着，无论使用标准 MSE 损失 (10.5)、广义 MSE 损失 (10.22)，还是完全不同的损失（只要它在 $z^{(L)}(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 时有最小值），解 (10.31) 都会忠实描述该最小值。¹⁶⁸

10.2.2 算法无关性

现在来讨论无限宽度极限的一个相关性质——到这里，它也已经完全在意料之中了：给定特定的初始化 $z_{i;\delta}^{(L)}(t=0)$ 与冻结 NTK $\Theta_{\delta\tilde{\alpha}_1}^{(L)}$ ，无论是通过一次巨大飞跃，还是通过一连串许多小步到达那里，我们总会抵达完全相同的最小值 (10.31)。也就是说，在无限宽度下存在**算法无关性**。

假设我们已经朝最小值迈出了 $T-1$ 步，使用的全局学习率为 $\eta(t)$ 、Newton 张量为 $\kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t)$ 、损失为 $\mathcal{L}_{\mathcal{A}}(t)$ ；一般来说，这些量都依赖步数 t 。对 $\eta(t)$ 、 $\kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t)$ 与 $\mathcal{L}_{\mathcal{A}}(t)$ 作出不同选择，会导出不同的优化算法；这一类包括 Newton 方法、梯度下降与随机梯度下降 (SGD)。¹⁶⁹ 迭代更新 (10.20)，网络输出累积的改变量为

$$z_{i;\delta}^{(L)}(T-1) = z_{i;\delta}^{(L)}(t=0) - \sum_{t=0}^{T-2} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \eta(t) \kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t) \epsilon_{i;\tilde{\alpha}_2}(t), \quad (10.33)$$

其中 $\epsilon_{i;\tilde{\alpha}_2}(t) \equiv \partial \mathcal{L}_{\mathcal{A}}(t) / \partial z_{i;\tilde{\alpha}_2}^{(L)}$ 是训练损失 $\mathcal{L}_{\mathcal{A}}(t)$ 的误差因子；该导数在第 t 步相对于网络输出 $z_{i;\tilde{\alpha}}^{(L)}(t)$ 求值。

再假设下一步 $t=T$ 到达真正最小值。为保证这一点，可以从 $z_{i;\delta}^{(L)}(T-1)$ 出发迈出一个 Newton 步，使得

$$z_{i;\delta}^{(L)}(T) = z_{i;\delta}^{(L)}(T-1) - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} \left[z_{i;\tilde{\alpha}_2}^{(L)}(T-1) - y_{i;\tilde{\alpha}_2} \right], \quad (10.34)$$

这里令 $\eta(T-1) \kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(T-1) = \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2}$ ，并在 $t=T-1$ 时选择标准 MSE 损失，使

¹⁶⁷ 无限宽度网络拥有无穷多个参数，所以在这一极限下网络能记住有限训练集，并不令人意外。

¹⁶⁸ 注意，解 (10.30) 依赖初始化时的网络输出 $z_{i;\delta}^{(L)}$ ，而后者最终取决于参数初始化 $\theta_{\text{init}} = \theta(t=0)$ 。对不同的初始化，我们会到达不同的解 (10.30)；其中每个解都会在给定相应初始化 θ_{init} 的条件下使损失达到最小。我们将在 §10.2.4 中进一步讨论这一点。

¹⁶⁹ 要看出它如何包含 SGD (7.10)，注意我们既可以在每一步 t 将损失限制为对不同批次 $\mathcal{S}_t \subset \mathcal{A}$ 的求和，即 $\mathcal{L}_{\mathcal{A}}(t) = \mathcal{L}_{\mathcal{S}_t}$ ；也可以等价地选择 Newton 张量 $\kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t)$ ，使其投影到子集 $\mathcal{S}_t$ 上。

$\epsilon_{i;\tilde{\alpha}_2}(T-1) = z_{i;\tilde{\alpha}_2}^{(L)}(T-1) - y_{i;\tilde{\alpha}_2}$.¹⁷⁰ 代入前 $T-1$ 步后的网络输出表达式 (10.33), 可见

$$\begin{aligned} z_{i;\delta}^{(L)}(T) &= z_{i;\delta}^{(L)}(t=0) - \sum_{t=0}^{T-2} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \eta(t) \kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t) \epsilon_{i;\tilde{\alpha}_2}(t) \\ &\quad - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)} \left\{ \left[z_{i;\tilde{\alpha}_2}^{(L)}(t=0) - \sum_{t=0}^{T-2} \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4} \tilde{\Theta}_{\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} \eta(t) \kappa^{\tilde{\alpha}_3\tilde{\alpha}_4}(t) \epsilon_{i;\tilde{\alpha}_4}(t) \right] - y_{i;\tilde{\alpha}_2} \right\} \\ &= z_{i;\delta}^{(L)}(t=0) - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)} \left[z_{i;\tilde{\alpha}_2}^{(L)}(t=0) - y_{i;\tilde{\alpha}_2} \right], \end{aligned} \quad (10.35)$$

从第二行到第三行时, 我们使用了 NTK 子矩阵之逆的定义方程 (10.26), 从而实现了抵消. 这个结果表明, 先前各步训练算法的全部细节 $\{\eta(t), \kappa^{\tilde{\alpha}_1\tilde{\alpha}_2}(t), \mathcal{L}_{\mathcal{A}}(t)\}_{t=0, \dots, T-2}$ 都被抹去了: 这里在最后一步 $t=T$ 之后, 方程 (10.35) 中的网络输出 $z_{i;\delta}^{(L)}(T)$, 与一次巨大飞跃 (10.31) 所到达的网络输出完全相同.¹⁷¹

因此, 在无限宽度极限下, 完全训练解由以下三项决定: (i) 冻结 NTK $\Theta_{\delta\tilde{\alpha}}^{(L)}$, 其细节取决于学习率张量 $\lambda_{\mu\nu}$ 中的训练超参数; (ii) 初始网络输出 $z_{i;\delta}^{(L)}(t=0)$, 其分布取决于初始化超参数; 以及 (iii) 训练集 $\mathcal{A}$ 的真实输出 $y_{i;\tilde{\alpha}}$. 至于使用了何种损失函数, 例如 MSE 或交叉熵; 迈出多少步才抵达最小值; 又或者采用梯度下降还是 SGD, 都无关紧要.¹⁷² 换一种说法, 算法无关性意味着这些超参数与训练集唯一指定了无限宽度极限下完全训练网络的统计量; Newton 方法只是一种径直到达该解的漂亮理论技巧. 如此一来, 我们可以用巨大飞跃解 (10.31) 研究所有这些不同优化算法的结果; 在简短插叙交叉熵损失之后, 我们就会这样做.

¹⁷⁰ 注意, 如果在第 $T-1$ 步已经到达最小值, 那么 (10.34) 中最后这个 Newton 步不会改变网络输出: $z_{i;\delta}^{(L)}(T) = z_{i;\delta}^{(L)}(T-1)$. 因此, 我们的论证也适用于任何用另外 $T-1$ 步便已到达最小值的算法; 实践中无须真的应用这个 Newton 步. 我们会在下一个脚注中再次讨论这一点.

¹⁷¹ 在 §∞.2.2 中, 我们会显式分析另一种优化算法的动力学——原始梯度下降 (7.11) 的许许多多步——并计算它相应的完全训练解. 正如算法无关性 (10.35) 所预期的, 在无限宽度极限下, 这个解与不同训练算法得到的其他解完全一致.

¹⁷² 以下是一些未能收入正文的补充评论:

- 直接实现 Newton 方法往往不切实际, 因为必须计算在整个训练集上求值的冻结 NTK 子矩阵之逆 $\tilde{\Theta}_{\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)}$; 这类似于 §6.3.2 中为贝叶斯推断求核的逆. 在精确贝叶斯推断的情形中, 我们考察的是学习算法是否可行; 与之不同, 这里的要点在于 Newton 方法是一种理论工具: 即使一个极宽网络实际上是用多步 (随机) 梯度下降训练的, 它也使我们可以描述该网络完全训练后的状态.
- 理论研究者经常取步长非常小的极限, 并用常微分方程 (ODE) 近似优化动力学. 这种近似有时会产生误导, 而这里表明它完全没有必要.
- 要让 SGD 真正收敛到最小值, 必须在训练过程中逐渐减小学习率; 否则网络只会在最小值附近涨落, 而永远不会真正抵达它. 直观上, 这是因为每一步的优化问题并不包含整个训练集.
- 好奇的读者或许会问, 如果无法按 Newton 方法迈出最后一步会怎样, 例如求冻结 NTK 子矩阵的逆并不切实际. 事实上, 如果在 $t=T-1$ 时已经接近最小值——也就是训练基本结束——那么精确落到最小值所需的最后一步将极其微小, 而解 (10.35) 就是迈出最后这次理论跳跃之前网络的一个很好近似.

10.2.3 插叙：交叉熵损失

现在作一段简短插叙，把交叉熵损失从脚注带入正文。一般而言，某个数据集 $\mathcal{D}$ 的交叉熵损失定义为

$$\mathcal{L}_{\mathcal{D}} = - \sum_{\delta \in \mathcal{D}} \sum_{i=1}^{n_{\text{out}}} p(i|x_{\delta}) \log[q(i|x_{\delta})], \quad (10.36)$$

其中 $p(i|x_{\delta})$ 是真实输出各分量 i 上的离散分布，

$$p(i|x_{\delta}) \equiv \frac{\exp[y_{i;\delta}]}{\sum_{j=1}^{n_{\text{out}}} \exp[y_{j;\delta}]}, \quad (10.37)$$

而 $q(i|x_{\delta})$ 类似地是网络输出各分量 i 上的离散分布，

$$q(i|x_{\delta}) \equiv \frac{\exp[z_{i;\delta}^{(L)}(t)]}{\sum_{j=1}^{n_{\text{out}}} \exp[z_{j;\delta}^{(L)}(t)]}. \quad (10.38)$$

正如我们在 §6.2.1 的贝叶斯模型拟合语境中讨论类别假设时所提到的，方程 (10.37) 与 (10.38) 使用的离散分布有时称为 *softmax* 分布 (6.11)。交叉熵损失 (10.36) 是衡量方程 (10.37) 与 (10.38) 这类离散分布接近程度的一种自然度量。¹⁷³

特别地，当我们想把输入 x 归入 n_{out} 个不同类别中的某一类时，交叉熵损失是分类问题的恰当选择。相应地，softmax 分布 (10.38) 把模型含 n_{out} 个实分量的输出向量变换为离散概率分布。与之相对，当希望学习的函数是实数向量时，MSE 损失是回归问题的恰当选择。¹⁷⁴ 重要的是，当初始化超参数被调至临界点、训练超参数又按照学习率等价原理选取时，两种损失在训练过程中都会表现良好。

使用交叉熵损失时，训练集的真实输出通常用 softmax 值 $p(i|x_{\bar{\alpha}})$ 给出，而不是用连续向量 $y_{i;\bar{\alpha}}$ 给出。更常见的是， $p(i|x_{\bar{\alpha}})$ 以绝对确定性 $p(i_{\bar{\alpha}}^*|x_{\bar{\alpha}}) = 1$ 指定某个特定标签 $i = i_{\bar{\alpha}}^*$ ，其余分量则消失，即对 $i \neq i_{\bar{\alpha}}^*$ 有 $p(i|x_{\bar{\alpha}}) = 0$ ；这称为硬标签或**独热编码**，并把网络输出的真实值 $y_{i_{\bar{\alpha}}^*;\bar{\alpha}}$ 置于无穷大。在这种情形下，有限次数的训练实际上不可能到达最小值；而在实践中，越接近这样的最小值，网络的泛化能力反而越差。为解决这一问题，可以把训练算法的**提前停止**用作正则化技术，从而有效得到有限的目标值 $y_{i_{\bar{\alpha}}^*;\bar{\alpha}}$ 。¹⁷⁵

现在回到无限宽度极限下训练神经网络的当前语境（并假定采用了上面所述的某种正则化）。上一小节已经指出：对于任何在训练集网络输出等于真实输出 $z^{(L)}(x_{\bar{\alpha}}; \theta) =$

¹⁷³严格来说，分布接近程度的恰当度量其实是 *Kullback–Leibler* (*KL*) 散度 (A.12)，我们将在附录 A 中详细说明。不过，KL 散度 $KL[p||q]$ 与交叉熵损失 (10.36) 仅相差一个与 $z^{(L)}$ 无关的常数；确切地说，这个常数就是熵 $\mathcal{S}[p(i|x_{\delta})] = - \sum_{\delta \in \mathcal{D}} \sum_{i=1}^{n_{\text{out}}} p(i|x_{\delta}) \log[p(i|x_{\delta})]$ 。因而，在任何基于梯度的学习算法下，使用二者中的哪一个完全等价。还要注意，两种损失对 p 与 q 都不具有交换对称性。方程 (10.36) 中的选择是有意为之，反映了未训练模型与产生观测的真实分布地位不同；这类似于贝叶斯推断中先验与后验之间的不对称性。

¹⁷⁴可以认为每种损失都源于不同的贝叶斯假设；比较我们在 §6.2.1 的贝叶斯模型拟合语境中，对不确定假设与 MSE 损失 (6.10)，以及类别假设与 softmax 分布 (6.11) 所作的讨论。

¹⁷⁵另一种办法是显式选择一个在输出类别上具有多个非零分量 $p(i|x_{\bar{\alpha}})$ 的目标分布，这称为软标签。它可以通过一种名为标签平滑的正则化技术实现，其中 $p(i_{\bar{\alpha}}^*|x_{\bar{\alpha}}) = 1 - \epsilon$ 且 $p(i \neq i_{\bar{\alpha}}^*|x_{\bar{\alpha}}) = \epsilon/(n_{\text{out}} - 1)$ ；如果确实想学习这样的输出类别分布，也可以采用 §6 脚注 120 中提到的知识蒸馏。

$y_{i;\tilde{\alpha}}$ 时达到最小值的损失，其最小值都由 Newton 方法的巨大飞跃解 (10.32) 描述。容易检验，当 $q(i|x_\delta) = p(i|x_\delta)$ 时，交叉熵损失 (10.36) 达到最小；再直接查看 (10.37) 与 (10.38)，便可看出条件 $z^{(L)}(x_{\tilde{\alpha}}; \theta) = y_{i;\tilde{\alpha}}$ 能实现这一点。

关于交叉熵损失，还需要补充一个重要说明。在这种设定中，我们以 softmax 分布 $p(i|x_{\tilde{\alpha}})$ 而非 n_L 分量实向量 $y_{i;\tilde{\alpha}}$ 指定真实输出，因此如何设定网络输出 $z_{i;\tilde{\alpha}}^{(L)}$ 存在歧义：任何与分量无关的平移 $y_{i;\tilde{\alpha}} \rightarrow y_{i;\tilde{\alpha}} + c_{\tilde{\alpha}}$ 都保持目标分布 $p(i|x_\delta)$ 不变。不过，我们在这里关心的并非网络输出 $z_{i;\delta}^{(L)}$ 本身，而是它们的 softmax 分布 $q(i|x_\delta)$ (10.38)，所以这一歧义最终无关紧要。特别地，在巨大飞跃解 (10.35) 中作平移 $y_{i;\tilde{\alpha}} \rightarrow y_{i;\tilde{\alpha}} + c_{\tilde{\alpha}}$ ，会让每个输入 x_δ 的所有输出分量都平移同一个量 $\sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\delta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} c_{\tilde{\alpha}_2}$ ，从而得到相同的 softmax 分布 $q(i|x_\delta)$ 。因此可以明确看出，我们的解 (10.35) 无歧义地描述了按照交叉熵损失完全训练的网络。

10.2.4 核预测

一种智能——无论是人工智能还是其他智能——经历密集的记忆过程之后，人们往往会用未见过的问题对它进行测试，以探查它是否真正理解。在机器学习中，我们通常要求模型对来自测试集 $\beta \in \mathcal{B}$ 的新输入 x_β 作出预测，以评估模型的理解程度。

在无限宽度极限下，完全训练 MLP 的预测由随机方程

$$z_{i;\beta}^{(L)}(T) = z_{i;\beta}^{(L)} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\beta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} \left(z_{i;\tilde{\alpha}_2}^{(L)} - y_{i;\tilde{\alpha}_2} \right), \quad (10.39)$$

控制；无论是用一步 (10.31) 还是多步 (10.35) 训练模型，也无论损失函数如何选择或学习算法还有什么其他细节，都是如此。¹⁷⁶ 为清楚起见，冻结 NTK 的逆 $\tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2}$ 只相对于 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 维训练集子矩阵求取，而冻结 NTK $\Theta_{\beta\tilde{\alpha}_1}^{(L)}$ 是完整冻结 NTK 的一个非对角分块，把训练集元素与测试集元素连接起来。还要注意，方程右边的网络输出 $z_{i;\delta}^{(L)}$ 在初始化时求值：再次强调，不带步数参数的可观测量应视为在初始化时求值，而带步数参数 T 的可观测量应视为在训练结束时求值。

随机方程 (10.39) 描述某个特定实例的完全训练神经网络所作的预测。随机性源自预测 (10.39) 对初始化网络输出 $z_{i;\delta}^{(L)}$ 的依赖，而这些输出本身又依赖初始化参数 $\theta_{\text{init}} \equiv \theta(t=0)$ 的具体实现。我们已经知道，这样的网络完全记住了训练集，因而 $z_{i;\tilde{\alpha}}^{(L)}(T) = y_{i;\tilde{\alpha}}$ ；这里的随机性意味着，系综中的任意给定网络都可能对测试集元素给出不同预测。

据此，现在计算整个完全训练网络系综的测试集预测分布。查看 (10.39) 可知，预测 $z_{i;\beta}^{(L)}(T)$ 是高斯分布初始输出 $z_{i;\delta}^{(L)}$ 的简单线性变换，因而它本身也是高斯的。平均预测直接为

$$m_{i;\beta}^\infty \equiv \mathbb{E} \left[z_{i;\beta}^{(L)}(T) \right] = \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\beta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} y_{i;\tilde{\alpha}_2}. \quad (10.40)$$

这个表达式与精确贝叶斯推断的无限宽度后验均值预测 (6.64) 完全类似，只需把所有类型的冻结神经正切核都替换成核： $\Theta^{(L)} \rightarrow K^{(L)}$ 。（很快还会详述。）与此同时，预

¹⁷⁶注意，§10.1 的分析既适用于一小步，也同样适用于巨大飞跃：完全训练的无限宽度网络在网络输出的向量分量之间没有连线 (§10.1.1)，也没有表征学习 (§10.1.2)。

测 (10.39) 的协方差为

$$\begin{aligned} \text{Cov} \left[z_{i_1; \hat{\beta}_1}^{(L)}(T), z_{i_2; \hat{\beta}_2}^{(L)}(T) \right] &\equiv \mathbb{E} \left[z_{i_1; \hat{\beta}_1}^{(L)}(T) z_{i_2; \hat{\beta}_2}^{(L)}(T) \right] - m_{i_1; \hat{\beta}_1}^\infty m_{i_2; \hat{\beta}_2}^\infty \\ &= \delta_{i_1 i_2} \left[K_{\hat{\beta}_1 \hat{\beta}_2}^{(L)} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\hat{\beta}_2 \tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} K_{\hat{\beta}_1 \tilde{\alpha}_2}^{(L)} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\hat{\beta}_1 \tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} K_{\hat{\beta}_2 \tilde{\alpha}_2}^{(L)} \right. \\ &\quad \left. + \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \Theta_{\hat{\beta}_1 \tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)} \Theta_{\hat{\beta}_2 \tilde{\alpha}_3}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} K_{\tilde{\alpha}_4 \tilde{\alpha}_2}^{(L)} \right]. \end{aligned} \quad (10.41)$$

这个表达式看起来有些复杂，同时涉及核与冻结 NTK；但作替换 $\Theta^{(L)} \rightarrow K^{(L)}$ 后，它也会约化为贝叶斯无限宽度后验协方差 (6.57).¹⁷⁷

网络预测系综 (10.39) 由其均值 (10.40) 与协方差 (10.41) 完全指定，并定义了一种**广义后验分布**。无论采取哪条路径到达训练终点，这一分布都为无限宽度网络系综在训练结束时提供了完整的闭式解。该分布的均值是对不同实例取平均后的网络预测，而协方差则量化这些预测在不同实例之间的涨落。

事实上，如果回想我们在 §6.2.1 中对贝叶斯推断近似方法的讨论，把训练网络的系综认作一种后验分布是合理的：使训练损失 $\mathcal{L}_{\mathcal{A}}(\theta)$ 最小化会给出模型参数的最大似然估计 (MLE) (6.21)；现在我们把它等同于完全训练解 (10.32)，即 $\theta_{\text{MLE}}^* = \theta_{\text{Newton}}^*$ 。再回想 §6.2.1 的脚注 103，对宽网络而言，损失的最小值并不唯一，而 MLE 方法会给出由初始化参数化的一族最小值： $\theta_{\text{MLE}}^*(\theta_{\text{init}})$ 。¹⁷⁸ 这种非唯一性最终源自完全训练网络的预测 $z_{i; \hat{\beta}}^{(L)}(T)$ 仍然依赖初始函数输出 $z_{i; \delta}^{(L)}$ ，而后者在不同实例之间随机变化；比较预测 (10.39)。考虑 θ_{init} 各实例构成的系综，现在便能准确看出，这个均值为 (10.40)、协方差为 (10.41) 的广义分布如何依赖训练超参数 $\lambda_b^{(\ell)}$ 与 $\lambda_W^{(\ell)}$ 、初始化超参数 $C_b^{(\ell)}$ 与 $C_W^{(\ell)}$ ，以及训练数据 $(x_{\tilde{\alpha}}, y_{\tilde{\alpha}})_{\tilde{\alpha} \in \mathcal{A}}$ 。

稍微较真地说，广义后验分布的协方差 (10.41)，与此前为无限宽度精确贝叶斯推断计算的后验协方差 (6.57)，其实有着不同解释。在基于梯度的学习中，输出协方差编码系综中各网络预测之间的差异；每个网络对应不同的参数设定，但都使训练损失 $\mathcal{L}_{\mathcal{A}}(\theta)$

¹⁷⁷ 精确贝叶斯推断与梯度下降一般会给出不同预测，这表明在一般超参数设定下，它们实际上是不同的学习算法。

¹⁷⁸ 按照同一个脚注，在无限宽度、基于梯度的学习语境中，我们也可以尝试分析在损失中加入形如 $\sum_{\mu=1}^P a_{\mu} \theta_{\mu}^2$ 的正则化项后得到的 MAP 估计 (6.22)。一旦开始这一分析，便会立即发现梯度下降更新 $d\theta_{\mu}$ 包含附加项 $-2\eta \sum_{\nu} \lambda_{\mu\nu} a_{\nu} \theta_{\nu}$ ；再稍加思考，很可能还会意识到需要定义一个新的随机张量

$$\hat{\mathcal{R}}_{i; \delta}^{(\ell)} \equiv \sum_{\mu, \nu} \lambda_{\mu\nu} a_{\mu} \theta_{\mu} \frac{dz_{i; \delta}^{(\ell)}}{d\theta_{\nu}}, \quad (10.42)$$

其随机迭代为

$$\hat{\mathcal{R}}_{i; \delta}^{(\ell+1)} = a_b^{(\ell+1)} \lambda_b^{(\ell+1)} b_i^{(\ell+1)} + a_W^{(\ell+1)} \frac{\lambda_W^{(\ell+1)}}{n_{\ell}} \sum_{j=1}^{n_{\ell}} W_{ij}^{(\ell+1)} \sigma_{j; \delta}^{(\ell)} + \sum_{j=1}^{n_{\ell}} W_{ij}^{(\ell+1)} \sigma'_{j; \delta}^{(\ell)} \hat{\mathcal{R}}_{j; \delta}^{(\ell)}, \quad (10.43)$$

接下来还要计算它与预激活的交叉相关。这里，需要为系数 a_{μ} 分别定义依赖层的偏置正则化与权重正则化，类似于 (8.6) 中对学习率张量所作的处理；作为附加练习，还可以求出这些正则化超参数与初始化超参数之间的相互作用。

最小. 在精确贝叶斯推断中, 协方差则编码我们对未见数据的内在不确定性, 而较小的不确定性可用作预测置信度的度量. 因此, 这些协方差产生于不同原因, 在认识论意义上有着截然不同的性质.

不过, 如果务实一点, 那么当手中有多个训练模型时, 把这种广义后验协方差 (10.41) 也看作置信度的一种度量, 并非完全不合理.

梯度下降等于精确贝叶斯推断的唯一情形

刚才我们随口注意到, 如果把所有冻结神经正切核都替换为核, 即 $\Theta^{(L)} \rightarrow K^{(L)}$, 那么基于 (10.39) 的广义后验分布便会约化为精确贝叶斯后验分布 (6.66). 现在来说明, 在基于梯度的学习中, 如何通过特定的训练超参数选择实际实现这一替换.

为说明具体做法, 把定义输出层核的递推 (4.118) 与定义输出层冻结 NTK 的递推 (9.5) 并列起来:

$$K_{\delta_1 \delta_2}^{(L)} = C_b^{(L)} + C_W^{(L)} \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(L-1)}}, \quad (10.44)$$

$$\Theta_{\delta_1 \delta_2}^{(L)} = \lambda_b^{(L)} + \lambda_W^{(L)} \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(L-1)}} + C_W^{(L)} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{K^{(L-1)}} \Theta_{\delta_1 \delta_2}^{(L-1)}. \quad (10.45)$$

直接观察可见, 把末层学习率设为

$$\lambda_b^{(L)} = C_b^{(L)}, \quad \lambda_W^{(L)} = C_W^{(L)}, \quad (10.46)$$

几乎就能得到所需结果:

$$\Theta_{\delta_1 \delta_2}^{(L)} = K_{\delta_1 \delta_2}^{(L)} + C_W^{(L)} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{K^{(L-1)}} \Theta_{\delta_1 \delta_2}^{(L-1)}. \quad (10.47)$$

要去掉最后那个讨厌的项, 需要设法让倒数第二层的冻结 NTK $\Theta_{\delta_1 \delta_2}^{(L-1)}$ 消失. 为保证这一点, 只需把所有其他训练超参数设为零:

$$\lambda_b^{(\ell)} = 0, \quad \lambda_W^{(\ell)} = 0, \quad \text{for } \ell < L. \quad (10.48)$$

结合 NTK 递推的初始条件 (8.23), 这保证对 $\ell < L$ 有 $\Theta_{\delta_1 \delta_2}^{(\ell)} = 0$, 其中包括 $\ell = L - 1$. 因此, 这一特定训练超参数配置使得

$$\Theta_{\delta_1 \delta_2}^{(L)} = K_{\delta_1 \delta_2}^{(L)}, \quad (10.49)$$

从而准确得到所需结果.

用文字来说, 训练超参数的选择 (10.46) 与 (10.48) 意味着只训练最后一层的偏置与权重. 这就确立了: 在无限宽度极限下, 精确贝叶斯推断实际上是基于梯度学习的网络系综的一个非常特殊的情形.

在实践中, 这意味着可以采用训练超参数选择 (10.46) 与 (10.48), 用梯度下降训练网络系综, 以实现精确贝叶斯推断很好的近似. (如果系综中有无穷多个网络, 该近似就会变得精确.) 一方面, 与 §6.3 中给出的精确贝叶斯推断版本不同, 此时不再需要显式存储核或求核的逆. 另一方面, 可能需要完全训练大量极宽网络, 系综才能给出良好近似; 这在计算量和内存方面可能再次变得昂贵.

有趣的是，显式关闭隐藏层中的学习，会显著改变用于计算预测的特征。特别地，此时 NTK 只包含来自最后一层偏置与权重的贡献。直观而言，这里是在倒数第二层取随机特征 $\sigma(z_i^{(L-1)})$ ，然后显式训练偏置 $b^{(L)}$ 与权重 $W^{(L)}$ ，以拟合这些随机特征所能给出的最佳线性模型。¹⁷⁹

10.3 泛化

如前所述，我们最终关心的是：模型在此前未见的测试集 $\mathcal{B}$ 上，相较于训练集 $\mathcal{A}$ 表现如何。某些完全训练的网络会比其他网络更好地泛化到这些新样本，而这强烈依赖其初始化与训练超参数。

为评估这一点，可以计算**泛化误差**：

$$\mathcal{E} \equiv \mathcal{L}_{\mathcal{B}} - \mathcal{L}_{\mathcal{A}}. \quad (10.50)$$

泛化误差定量衡量网络究竟能多好地逼近目标函数。¹⁸⁰ 具体来说，如果训练损失很小、测试损失却很大，以至于泛化误差显著，那么网络并非 $f(x)$ 的良好模型；它只是一张查询表，记录了从训练集 $\mathcal{A}$ 取 x 时的 $f(x)$ 值。这称为**过拟合**。相反，如果训练损失和测试损失都很小，因而泛化误差也很小，那么我们预期模型已经超越了简单记忆。¹⁸¹ 因此，泛化误差常被视为衡量机器学习模型是否成功的主要定量指标。

在无限宽度极限下，上一节已经看到，对任意特定网络都很容易令训练损失为零，即 $\mathcal{L}_{\mathcal{A}} = 0$ 。因而在当前语境中，泛化误差完全由测试损失评估：

$$\mathcal{E} = \mathcal{L}_{\mathcal{B}}, \quad (10.51)$$

当前目标就是理解测试误差的统计量，以刻画无限宽度网络如何泛化。

对于宽网络，我们知道存在许多能使训练损失最小并记住训练数据的模型参数配置。其中有些配置可能泛化良好，从而测试损失很小；另一些则可能过拟合，从而测试损失很大。因此，泛化误差的统计量由这些配置的统计量决定，而后者又由初始化超参数与训练超参数决定。

平均泛化误差刻画网络系综的泛化性质，而它的方差告诉我们，不同实例之间的涨落如何使某些特定网络比其他网络泛化得更好。理解这些统计量，可以指导我们选择超参数，使平均泛化性能达到最佳，同时确保任意完全训练网络的典型行为都很可能接近平均行为。¹⁸²

¹⁷⁹我们将在 §10.4 中解释，无限宽度极限下基于梯度的学习的一般版本同样是随机特征的线性模型，只是由涵盖所有隐藏层的一组更大的此类特征构造而成。

¹⁸⁰不失一般性，下文将隐含地假设损失的最小值为零。

¹⁸¹如果泛化误差 $\mathcal{E}$ 很小，但训练损失 $\mathcal{L}_{\mathcal{A}}$ 很大，则称模型欠拟合。这种情况对很宽的网络并不真正相关，因为正如已经解释过的，我们可以把它们完全训练到训练损失为零。

¹⁸²在机器学习的某些应用中，未见样本还会进一步分成两类数据集：(i) 验证集，一般用于模型选择，尤其常用于调节超参数；以及 (ii) 测试集，用于评估某个特定已训练模型的泛化性质。尽管本文宽泛地使用测试集一词，但这里我们解析计算未见样本上的损失统计量，再用它们调节超参数；因而从含义上说，这其实更接近验证集，因为我们是在调节模型系综，而不是评估某个特定模型。

据此，先计算在完全训练网络系综上取平均的 MSE 测试损失：

$$\begin{aligned}
 \mathbb{E}[\mathcal{L}_{\mathcal{B}}(T)] &= \mathbb{E} \left[\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\beta \in \mathcal{B}} \left(z_{i;\beta}^{(L)}(T) - y_{i;\beta} \right)^2 \right] \\
 &= \mathbb{E} \left[\frac{1}{2} \sum_{i=1}^{n_L} \sum_{\beta \in \mathcal{B}} \left(z_{i;\beta}^{(L)}(T) - m_{i;\beta}^{\infty} + m_{i;\beta}^{\infty} - y_{i;\beta} \right)^2 \right] \\
 &= \frac{1}{2} \sum_{\beta \in \mathcal{B}} \left\{ \sum_{i=1}^{n_L} \left(m_{i;\beta}^{\infty} - y_{i;\beta} \right)^2 + \sum_{i=1}^{n_L} \text{Cov} \left[z_{i;\beta}^{(L)}(T), z_{i;\beta}^{(L)}(T) \right] \right\}. \quad (10.52)
 \end{aligned}$$

第二行中，我们加上又减去了无限宽度平均预测 (10.40)；为得到第三行，则注意到交叉项在取期望后抵消。

分解 (10.52) 展示了一种广义**偏差-方差权衡**：第一项即偏差，衡量系综平均预测 $m_{i;\beta}^{\infty}$ 与真实输出 $y_{i;\beta}$ 的偏离；第二项即方差——具体而言，是广义后验分布的协方差 (10.41)——衡量该预测在系综不同模型实例之间的涨落。之所以称为权衡，是因为不同的超参数设定通常会以增大一项为代价减小另一项，迫使建模者在二者之间作出选择。¹⁸³

对于更一般的损失，可以在平均预测附近 Taylor 展开测试损失：

$$\begin{aligned}
 \mathcal{L}_{\mathcal{B}} &= \mathcal{L}_{\mathcal{B}}(m^{\infty}) + \sum_{i,\beta} \frac{\partial \mathcal{L}_{\mathcal{B}}}{\partial z_{i;\beta}^{(L)}} \bigg|_{z^{(L)}=m^{\infty}} \left(z_{i;\beta}^{(L)}(T) - m_{i;\beta}^{\infty} \right) \\
 &\quad + \frac{1}{2} \sum_{i_1, i_2, \beta_1, \beta_2} \frac{\partial^2 \mathcal{L}_{\mathcal{B}}}{\partial z_{i_1;\beta_1}^{(L)} \partial z_{i_2;\beta_2}^{(L)}} \bigg|_{z^{(L)}=m^{\infty}} \left(z_{i_1;\beta_1}^{(L)}(T) - m_{i_1;\beta_1}^{\infty} \right) \left(z_{i_2;\beta_2}^{(L)}(T) - m_{i_2;\beta_2}^{\infty} \right) + \dots, \quad (10.53)
 \end{aligned}$$

其中，把在平均预测处求值的测试损失记为

$$\mathcal{L}_{\mathcal{B}}(m^{\infty}) \equiv \mathcal{L}_{\mathcal{B}}(z^{(L)} = m^{\infty}). \quad (10.54)$$

对系综取期望，并注意由定义 (10.40) 有 $\mathbb{E} \left[z_{i;\beta}^{(L)}(T) - m_{i;\beta}^{\infty} \right] = 0$ ，得到

$$\mathbb{E}[\mathcal{L}_{\mathcal{B}}] = \mathcal{L}_{\mathcal{B}}(m^{\infty}) + \frac{1}{2} \sum_{i_1, i_2, \beta_1, \beta_2} \frac{\partial^2 \mathcal{L}_{\mathcal{B}}}{\partial z_{i_1;\beta_1}^{(L)} \partial z_{i_2;\beta_2}^{(L)}} \bigg|_{z^{(L)}=m^{\infty}} \text{Cov} \left[z_{i_1;\beta_1}^{(L)}(T), z_{i_2;\beta_2}^{(L)}(T) \right] + \dots \quad (10.55)$$

这里再次得到一种广义偏差-方差分解：第一项 $\mathcal{L}_{\mathcal{B}}(m^{\infty})$ 是偏差，衡量平均预测与测试集真实输出的偏离；第二项是方差，它以协方差与损失关于网络输出的 Hessian 矩阵之乘积的迹，衡量不同实例之间的不确定性。因而对任意损失函数，只要模型给出的预测接近平均预测，这些偏差项与方差项就能很好地代理泛化误差 $\mathcal{E}$ 。

¹⁸³之所以称其为广义偏差-方差权衡，是因为在标准偏差-方差权衡中，期望是对训练集 $\mathcal{A}$ 的不同实现取的，而不是对模型参数 θ_{μ} 的不同初始化取的。在典型设定中，我们只有一个模型；偏差刻画该模型在每个不同训练集上能被训练得多好——较大偏差表明欠拟合；方差则刻画模型性能在不同训练集之间的涨落——较大方差表明过拟合。

现在来看如何在几种不同设定中计算这些偏差项与方差项. 实践中最常见的情形是, 损失对样本具有广延性或可加性, 即 $\mathcal{L}_{\mathcal{B}} = \sum_{\beta \in \mathcal{B}} \mathcal{L}_{\beta}$; 于是可以每次只考察一个测试样本上的测试损失. 因此, 这里的分析问题是: 对一个给定测试输入, 需要多少训练样本才能作出预测?

在 §10.3.1 中, 我们会使用 §5 引入的 δ 展开, 围绕一个训练样本计算泛化误差 (10.55) 的偏差项与方差项; 这将从另一个角度揭示两个普适类的超参数调节与临界性. 不过, 由于训练集被限制为一个样本, 这一视角会有一定局限.

在 §10.3.2 中, 我们会把训练集扩大到包含两个样本. 这里不再计算泛化误差本身, 而是可以直接探索泛化的另一个方面: 完全训练的网络如何通过内插或外推作出预测.

10.3.1 偏差-方差权衡与临界性

用 $\tilde{\alpha} = +$ 标记一个训练样本, 用 $\tilde{\beta} = -$ 标记附近的一个测试样本; 同时聚焦输出层 $\ell = L$, 并暂时省略冻结 NTK 的层指标, 记 $\Theta_{\delta_1 \delta_2} \equiv \Theta_{\delta_1 \delta_2}^{(L)}$, 直到稍后需要讨论各 NTK 分量的深度依赖性时再恢复.

泛化误差的偏差项由平均预测 (10.40) 相对于真实输出的偏离决定:

$$\begin{aligned} m_{i;-}^{\infty} - y_{i;-} &= \frac{\Theta_{-+}}{\Theta_{++}} y_{i;+} - y_{i;-} \\ &= (y_{i;+} - y_{i;-}) + \left(\frac{\Theta_{-+}}{\Theta_{++}} - 1 \right) y_{i;+}. \end{aligned} \quad (10.56)$$

第一项是两个不同输入上的真实函数输出之差 $f(x_+) - f(x_-)$, 第二项则是我们在 x_- 上的预测输出与在 x_+ 上学到的真实输出之间类似的 (期望) 差 $z_-(T) - z_+(T)$.¹⁸⁴ 注意这两项中 $+$ 与 $-$ 的次序相反: 若预测完全正确, 两项大小相等、符号相反, 泛化误差的偏差项便消失.

据此, 偏差项 (10.56) 第二因子括号中的量

$$\frac{\Theta_{-+}}{\Theta_{++}} - 1, \quad (10.57)$$

自然可作为鲁棒性的度量, 因为它刻画输入发生相应小变化时预测变化的敏感程度, 即 $|z_-(T) - z_+(T)|$ 如何增长. 不鲁棒的模型往往会出错, 其预测会显著偏离附近训练点上的网络输出; 但过于鲁棒的模型又缺乏输出灵活性. 由于事先不知道要逼近哪类函数, 我们自然希望超参数所包含的网络类别既鲁棒, 又不过分僵化.¹⁸⁵

现在, 测试输入靠近训练输入, 这应让人想起 §5.1 临界性分析中的 δ 展开.¹⁸⁶ 具体而言, 仿照 (5.15) 对核的处理, 在 $\gamma^{[a]}$ 基中展开冻结 NTK:

$$\Theta_{\pm\pm} = \Theta_{[0]} \pm \Theta_{[1]} + \Theta_{[2]}, \quad \Theta_{\pm\mp} = \Theta_{[0]} - \Theta_{[2]}, \quad (10.58)$$

¹⁸⁴一般而言, 泛化误差 (10.55) 中的偏差项 $\mathcal{L}_{\mathcal{B}}(m^{\infty})$ 依赖损失的具体形式. 可以围绕真实输出 $y_{i;-}$ 展开 $\mathcal{L}_{\mathcal{B}}(m^{\infty})$, 而展开将依赖差值 $m_{i;-}^{\infty} - y_{i;-}$ (10.56). 对 MSE 损失, 偏差恰为该差值的平方. 对交叉熵损失, 更自然的是按差值 $\bar{q}(i|x_-) - p(i|x_-)$ 展开, 其中 $\bar{q}(i|x_{\delta}) \equiv \exp[m_{i;\delta}^{\infty}] / \sum_{j=1}^{n_{\text{out}}} \exp[m_{j;\delta}^{\infty}]$.

¹⁸⁵细心的读者可能会注意到, 这与 §6.3.1 中关于临界性的论证相呼应: 在那里我们考察真实输出不同的两个输入的证据, 即 $f(x_+) - f(x_-) \neq 0$, 同样要求函数逼近器的选择具有适当灵活性.

¹⁸⁶以下分析适用于光滑激活函数, 旨在给出总体图景. 稍后专门讨论非线性尺度不变激活函数时, 我们会给出适用于它们的分析.

并作类似于核的 (5.22)–(5.24) 的 δ 展开:

$$\Theta_{[0]} = \Theta_{00} + \delta\delta\Theta_{[0]} + O(\delta^4), \quad (10.59)$$

$$\Theta_{[1]} = \delta\Theta_{[1]} + O(\delta^3), \quad (10.60)$$

$$\Theta_{[2]} = \delta\delta\Theta_{[2]} + O(\delta^4), \quad (10.61)$$

这里展开中心是中点输入 $x_{i;0} \equiv (x_{i;+} + x_{i;-})/2$ 上求值的中点冻结 NTK Θ_{00} .

为简化表述, 假设两个输入具有相同范数 $\sum_{i=1}^{n_0} x_{i;+}^2 = \sum_{i=1}^{n_0} x_{i;-}^2$, 于是 $K_{[1]} = 0$ 且 $\Theta_{[1]} = (\Theta_{++} - \Theta_{--})/2 = 0$. 将分解 (10.58) 以及展开 (10.59)、(10.61) 代入鲁棒性度量 (10.57), 得到

$$\frac{\Theta_{-+}}{\Theta_{++}} - 1 = \left(\frac{\Theta_{[0]} - \Theta_{[2]}}{\Theta_{[0]} + \Theta_{[2]}} - 1 \right) = -2 \frac{\delta\delta\Theta_{[2]}}{\Theta_{00}} + O(\delta^4). \quad (10.62)$$

因此, 比值 $\delta\delta\Theta_{[2]}/\Theta_{00}$ 捕捉了对附近测试输入作预测时的鲁棒性. 稍后将分析它在两个普适类中的深度依赖性.

讨论完泛化误差的偏差项, 接着考虑方差项. 方差中与损失无关的部分由广义后验分布的协方差 (10.41) 给出. 对单个训练样本 $\tilde{\alpha} = +$ 计算 (10.41), 使用核的分解 (5.15)、冻结 NTK 的分解 (10.58), 再使用展开 (5.22)、(5.24)、(10.59) 和 (10.61), 得到

$$\begin{aligned} & \text{Cov} \left[z_{i;-}^{(L)}(T), z_{i;-}^{(L)}(T) \right] \\ &= K_{--} - 2 \frac{\Theta_{-+}}{\Theta_{++}} K_{-+} + \left(\frac{\Theta_{-+}}{\Theta_{++}} \right)^2 K_{++} \\ &= K_{[0]} + K_{[2]} - 2 \left(\frac{\Theta_{[0]} - \Theta_{[2]}}{\Theta_{[0]} + \Theta_{[2]}} \right) (K_{[0]} - K_{[2]}) + \left(\frac{\Theta_{[0]} - \Theta_{[2]}}{\Theta_{[0]} + \Theta_{[2]}} \right)^2 (K_{[0]} + K_{[2]}) \\ &= 4\delta\delta K_{[2]} + O(\delta^4). \end{aligned} \quad (10.63)$$

所以在领先阶, 方差项只依赖核的垂直扰动 $\delta\delta K_{[2]}$.

关于 $\delta\delta K_{[2]}$ 在各普适类中如何随深度变化, 我们已经掌握了全部信息 (参见 §5.3 与 §5.5). 一方面, 可以选择使其随深度指数增长的初始化超参数, 但方差项也会迅速增长, 导致不同实现之间的模型预测剧烈涨落. 另一方面, 可以选择使其指数衰减的初始化超参数, 得到迅速消失的方差项和过度自信的预测. 然而这种自信有代价: 指数消失的 $\delta\delta K_{[2]}$ 意味着冻结 NTK 分量 $\delta\delta\Theta_{[2]}$ 也指数消失, 于是鲁棒性度量 (10.62) 趋于零, 表明模型极端僵化. 具体而言, 无论输入为何, 学到的都只是恒等于 y_+ 的常函数.

这正是上文所述的广义偏差–方差权衡: 若让 $\delta\delta K_{[2]}$ 指数消失以把方差压到零, 那么 $\delta\delta\Theta_{[2]}$ 的消失会增大一般输入上的偏差, 网络便无法以非平凡方式泛化. 反过来, 较大的 $\delta\delta\Theta_{[2]}$ 使函数过于灵活, 不仅让预测对输入的小变化过于敏感, 还会通过 $\delta\delta K_{[2]}$ 导致预测在不同实现间剧烈涨落.

当然还有第三种选择: 采用临界性条件 $\chi_{\perp}(K^*) = 1$. 这种初始化超参数设定有望平衡偏差–方差权衡, 而无须事先知道待建模数据集的更多信息.

另一个临界性条件 $\chi_{\parallel}(K^*) = 1$ 又如何? 回顾 §9.4 对梯度爆炸与消失问题的讨论, 平行敏感度 $\chi_{\parallel}$ 影响中点冻结 NTK Θ_{00} 接收不同层贡献的方式. 由于 Θ_{00} 如 (10.62) 所

示进入鲁棒性度量，它也应在泛化中扮演重要角色。事实上，稍后在 §10.4 会看到，确保所有层等量贡献，也就是在预测时使用可获得的最大特征集合。因而把 $\chi_{\parallel}(K^*) = 1$ 与 $\chi_{\perp}(K^*) = 1$ 同时选作临界性条件，是泛化的自然选择，也是支持该选择的又一条证据。¹⁸⁷

回到泛化误差的偏差部分，为完成分析，需要求解冻结 NTK 递归 (9.5) 中 $\delta\delta\Theta_{[2]}$ 分量的递归；完整式重印如下：

$$\Theta_{\delta_1\delta_2}^{(\ell+1)} = \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(\ell)}} + C_W \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{K^{(\ell)}} \Theta_{\delta_1\delta_2}^{(\ell)}. \quad (10.67)$$

先处理 $K^* = 0$ 普适类，再考虑尺度不变普适类；后者需要使用 §5.5 的有限角结果。到这里，两种计算对我们都只是小儿科。¹⁸⁸

$K^* = 0$ 普适类

回顾很早以前的 (5.44)，它描述了两个激活的 Gaussian 期望在 $\gamma^{[a]}$ 基中的分解。关闭平行扰动，即 $K_{[1]}^{(\ell)} = 0$ 后，展开为

$$\langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(\ell)}} = \left[\langle \sigma \sigma \rangle_{K_{00}^{(\ell)}} + O(\delta^2) \right] \gamma_{\delta_1\delta_2}^{[0]} + \left[\delta \delta K_{[2]}^{(\ell)} \langle \sigma' \sigma' \rangle_{K_{00}^{(\ell)}} + O(\delta^4) \right] \gamma_{\delta_1\delta_2}^{[2]}. \quad (10.68)$$

作替换 $\sigma \rightarrow \sigma'$ ，得到激活导数的 Gaussian 期望的类似分解：

$$\langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{K^{(\ell)}} = \left[\langle \sigma' \sigma' \rangle_{K_{00}^{(\ell)}} + O(\delta^2) \right] \gamma_{\delta_1\delta_2}^{[0]} + \left[\delta \delta K_{[2]}^{(\ell)} \langle \sigma'' \sigma'' \rangle_{K_{00}^{(\ell)}} + O(\delta^4) \right] \gamma_{\delta_1\delta_2}^{[2]}. \quad (10.69)$$

¹⁸⁷与 §6.3.1 的脚注 115 一样，考虑范数不等的两个输入 $\sum_i x_{i,+}^2 \neq \sum_i x_{i,-}^2$ 可给出进一步理由。此时鲁棒性度量为

$$\frac{\Theta_{-+}}{\Theta_{++}} - 1 = -\frac{\delta\Theta_{[1]}}{\Theta_{00}} - 2\frac{\delta\delta\Theta_{[2]}}{\Theta_{00}} + \left(\frac{\delta\Theta_{[1]}}{\Theta_{00}} \right)^2 + O(\delta^3), \quad (10.64)$$

而协方差为

$$\text{Cov} \left[z_{i,-}^{(L)}(T), z_{i,-}^{(L)}(T) \right] = 4\delta\delta K_{[2]} - 2\delta K_{[1]} \frac{\delta\Theta_{[1]}}{\Theta_{00}} + K_{00} \left(\frac{\delta\Theta_{[1]}}{\Theta_{00}} \right)^2 + O(\delta^3). \quad (10.65)$$

核分量 $\delta K_{[1]}$ 与 K_{00} 都有贡献，因此须依照先前讨论设 $\chi_{\parallel} = 1$ ；此外还须驯服 $\delta\Theta_{[1]}$ 的爆炸与消失。对尺度不变普适类， $\Theta_{[1]} = (\Theta_{++} - \Theta_{--})/2$ 与单输入冻结 NTK (9.44) 具有完全相同的深度依赖性。此时 $\chi_{\parallel} = \chi_{\perp} \equiv \chi$ ，取 $\chi = 1$ 即可缓解所有指数爆炸与消失。对 $K^* = 0$ 普适类，利用 (5.20) 从完整递归 (10.67) 投影出 $\gamma^{[1]}$ 分量，可写出

$$\delta\Theta_{[1]}^{(\ell+1)} = \chi_{\perp}^{(\ell)} \delta\Theta_{[1]}^{(\ell)} + \left(\frac{\lambda_W^{(\ell+1)}}{C_W} \chi_{\parallel}^{(\ell)} + \frac{C_W}{K_{00}^{(\ell)}} \langle z \sigma' \sigma'' \rangle_{K_{00}^{(\ell)}} \Theta_{00}^{(\ell)} \right) \delta K_{[1]}^{(\ell)}, \quad (10.66)$$

其推导几乎与下文 $\delta\delta\Theta_{[2]}$ 的推导 (10.70) 同构。这里 $\delta K_{[1]}^{(\ell)}$ 对 $\delta\Theta_{[1]}^{(\ell)}$ 有贡献；按 §10.2.4 的讨论，可把它视为 Bayesian 贡献。取 $\chi_{\parallel}(K^*) = 1$ 可缓解它的爆炸与消失问题，参见 (5.47)。此时不妨重读并反思 §6.3.1 脚注 115 的最后一段。进一步研究临界点处的深度依赖性会发现， $\delta\Theta_{[1]}^{(\ell)}$ 比 $\Theta_{00}^{(\ell)}$ 和 $\delta\delta\Theta_{[2]}^{(\ell)}$ 衰减得更快，问题遂归结为正文所研究的情形。

¹⁸⁸更小小儿科的玩法是研究泛化误差的 Bayesian 版本：依照 (10.46) 与 (10.48) 设定训练超参数，使 $\Theta_{\delta_1\delta_2}^{(L)} = K_{\delta_1\delta_2}^{(L)}$ 。此时偏差项和方差项的行为完全已知。这是一种非常特殊的训练超参数设定，通常不太可能最优（参见 §10.4 关于冻结 NTK 与 Bayesian 核的特征函数差异的讨论）。对尺度不变普适类，我们将在 (10.94) 附近明确看到，精确 Bayesian 推断的渐近行为劣于更一般的基于梯度的学习。

将这些展开代入完整冻结 NTK 递归 (10.67), 并利用逐分量恒等式 $\gamma^{[0]}\gamma^{[0]} = \gamma^{[2]}\gamma^{[2]} = \gamma^{[0]}$ 与 $\gamma^{[0]}\gamma^{[2]} = \gamma^{[2]}$, 得到

$$\delta\delta\Theta_{[2]}^{(\ell+1)} = \chi_{\perp}^{(\ell)}\delta\delta\Theta_{[2]}^{(\ell)} + \left(\frac{\lambda_W^{(\ell+1)}}{C_W}\chi_{\perp}^{(\ell)} + C_W \langle \sigma''\sigma'' \rangle_{K_{00}^{(\ell)}} \Theta_{00}^{(\ell)} \right) \delta\delta K_{[2]}^{(\ell)}, \quad (10.70)$$

其中用到了垂直敏感度 (5.51) 的定义 $\chi_{\perp}^{(\ell)} = C_W \langle \sigma'\sigma' \rangle_{K_{00}^{(\ell)}}$.¹⁸⁹

我们早已知道垂直敏感度控制垂直扰动 $\delta\delta K_{[2]}^{(\ell)}$ 的行为; 由 (10.70) 可见, 它也控制冻结 NTK 分量 $\delta\delta\Theta_{[2]}^{(\ell)}$. 因而二者的指数衰减或增长彼此关联. 若令前者指数衰减以消除泛化误差的方差项, 后者也会指数衰减, 使模型预测成为常数、缺乏灵活性并具有很大的偏差.

结合平行敏感度 $\chi_{\parallel}$ 的作用, 现在调至临界性 $\chi_{\parallel}(K^*) = \chi_{\perp}(K^*) = 1$, 求 $\delta\delta\Theta_{[2]}^{(\ell)}$ 的深度依赖性. 对 $K^* = 0$ 普适类, 临界性 (5.90) 由 $C_b = 0$, $C_W = 1/\sigma_1^2$ 给出. 回顾 (5.92) 与 (5.99) 的大 ℓ 渐近解

$$K_{00}^{(\ell)} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \dots, \quad \delta\delta K_{[2]}^{(\ell)} = \frac{\delta^2}{\ell^{p_{\perp}}} + \dots, \quad (10.71)$$

其中 $p_{\perp} \equiv b_1/a_1$, 依赖激活函数的常数 a_1, b_1 定义于 (5.86)、(5.88), 而 δ^2 与输入的初始间隔有关, 却不由渐近分析确定. 由 (9.76) 还可渐近展开

$$\chi_{\perp}^{(\ell)} = 1 - \frac{p_{\perp}}{\ell} + \dots \quad (10.72)$$

简单的 Gaussian 积分给出

$$\langle \sigma''\sigma'' \rangle_{K_{00}^{(\ell)}} = \sigma_2^2 + O\left(K_{00}^{(\ell)}\right) = \sigma_2^2 + O\left(\frac{1}{\ell}\right), \quad (10.73)$$

其中 $\sigma_2 \equiv \sigma''(0)$.

接着还须选择训练超参数 $\lambda_b^{(\ell)}$ 与 $\lambda_W^{(\ell)}$. 泛化误差的深度标度依赖这些超参数并不意外, 因为相对学习率的选择理应影响模型性能. 先遵循 §9.4 的学习率等效原理, 依照 (9.95) 设定训练超参数, 即把 (9.70) 乘以 $L^{p_{\perp}-1}$:

$$\lambda_b^{(\ell)} = \tilde{\lambda}_b \left(\frac{1}{\ell} \right)^{p_{\perp}} L^{p_{\perp}-1}, \quad \lambda_W^{(\ell)} = \tilde{\lambda}_W \left(\frac{L}{\ell} \right)^{p_{\perp}-1}. \quad (10.74)$$

由此得到中点冻结 NTK 的渐近解, 它与 (9.71) 相同, 只多出因子 $L^{p_{\perp}-1}$:

$$\Theta_{00}^{(\ell)} = \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{L}{\ell} \right)^{p_{\perp}-1} + \dots \quad (10.75)$$

把 (10.71)–(10.75) 代入 (10.70), 得到

$$\begin{aligned} \delta\delta\Theta_{[2]}^{(\ell+1)} &= \left[1 - \frac{p_{\perp}}{\ell} + \dots \right] \delta\delta\Theta_{[2]}^{(\ell)} \\ &+ \delta^2 \left\{ \tilde{\lambda}_W \sigma_1^2 + \frac{\sigma_2^2}{\sigma_1^2} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \right\} L^{p_{\perp}-1} \left(\frac{1}{\ell} \right)^{2p_{\perp}-1} + \dots \end{aligned} \quad (10.76)$$

¹⁸⁹更一般地, $\delta\delta\Theta_{[2]}$ 的递归还含有正比于 $(\delta K_{[1]})^2$ 和 $\delta K_{[1]}\delta\Theta_{[1]}$ 的项; 但训练输入与测试输入范数相等时 $\delta K_{[1]} = 0$, 这些项消失.

用惯常方法在渐近大 ℓ 极限求解：

$$\delta\delta\Theta_{[2]}^{(\ell)} = \delta^2 \frac{L^{p_\perp-1}}{(2-p_\perp)} \left\{ \tilde{\lambda}_W \sigma_1^2 + \frac{\sigma_2^2}{\sigma_1^2} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \right\} \left(\frac{1}{\ell} \right)^{2p_\perp-2} + \dots \quad (10.77)$$

最后取中点冻结 NTK (10.75) 与垂直扰动 (10.77) 的比，并在输出层 $\ell = L$ 求值，得到鲁棒性度量的总网络深度依赖性：

$$\frac{-2\delta\delta\Theta_{[2]}^{(L)}}{\Theta_{00}^{(L)}} = \frac{2\delta^2}{(p_\perp-2)} \left\{ \frac{\tilde{\lambda}_W \sigma_1^2}{\left[\tilde{\lambda}_b + (\tilde{\lambda}_W \sigma_1^2)/(-a_1) \right]} + \frac{\sigma_2^2}{\sigma_1^2} \right\} L^{1-p_\perp} \propto L^{1-p_\perp}. \quad (10.78)$$

这很惊人：要求极深网络的鲁棒性度量保持为一阶量，恰好挑出了该普适类中 $p_\perp = 1$ 的激活函数！¹⁹⁰ 任意奇 $K^* = 0$ 激活函数都满足此条件，例如全书反复讨论的 $\tanh$ 与 $\sin$ 。

现在退一步，从更宽广的角度审视这些计算。多少有些神奇的是，理论动机驱动的全部超参数调节——用临界性调节初始化超参数，用学习率等效原理调节训练超参数——在一训练样本、一测试样本的设定中给出了实践上最优的泛化误差解，控制住了偏差-方差权衡。更重要的是，这些选择与解对许多不同的网络宽度和深度都很鲁棒，因而对实验及模型扩展十分有用。¹⁹¹ 当然，这并非真正的奇迹：我们的理论原理从一开始就受实践问题驱动。

既然明白了应该怎样做，再讨论一种不应该采用的训练超参数选择。若不遵循学习率等效原理，也许会简单地令权重与偏置学习率逐层不变，即 $\lambda_b^{(\ell)} = \lambda_b$ 、 $\lambda_W^{(\ell)} = \lambda_W$ 。为简化起见，专门考虑 $\sigma_2 = 0$ 、 $p_\perp = 1$ 的奇激活函数。此时单输入冻结 NTK 的一般形式解 (9.69) 化为

$$\Theta_{00}^{(\ell)} = \left(\frac{\lambda_b}{2} \right) \ell + \dots, \quad (10.79)$$

它线性依赖层数 ℓ ；而按上述同一计算并取 $\sigma_2 = 0$ 、 $p_\perp = 1$ ， $\delta\delta\Theta_{[2]}^{(\ell)}$ 的渐近解是不依赖层数的常数：

$$\delta\delta\Theta_{[2]}^{(\ell)} = \lambda_W \sigma_1^2 \delta^2 + \dots \quad (10.80)$$

两者结合，鲁棒性度量成为

$$\frac{-2\delta\delta\Theta_{[2]}^{(L)}}{\Theta_{00}^{(L)}} = \left[\frac{-4\lambda_W \sigma_1^2 \delta^2}{\lambda_b} \right] \frac{1}{L} + \dots, \quad (10.81)$$

它会随网络总深度 L 缓慢却确定地衰减。考虑更一般的 $p_\perp \neq 1$ 激活函数也不会改变这一结论。因而与基于等效原理的选择相比，这种训练超参数选择在多项式意义下次优。¹⁹²

¹⁹⁰ 由 $p_\perp = b_1/a_1$ (参见 (5.99))、 $b_1 \geq a_1$ (参见 (5.86)、(5.88)) 以及 $a_1 < 0$ (参见 (5.92))，可知任意 $K^* = 0$ 激活函数都有 $p_\perp \leq 1$ 。特别地，对 $\sigma_2 \neq 0$ 的非奇激活函数，垂直扰动指数严格小于一，即 $p_\perp < 1$ ，所以泛化误差 (10.56) 的偏差项会随网络深度 L 增长。

¹⁹¹ 即使放松无限宽度要求，允许非零纵横比 $L/n \ll 1$ ，这些调节大体仍然有效。

¹⁹² 留给读者检验：若不像 (8.6) 那样按前一层宽度重缩放权重学习率，从而更严重地违背学习率等效原理，一训练样本、一测试样本的泛化误差会糟糕到何种程度。

回头看, 最初通过形式解 (9.69) 讨论学习率等效原理时, 我们的动机是确保各层对 NTK 作等量贡献. 随后在 §9.4 认识到, 这些选择解决了梯度爆炸与消失问题的多项式版本. 此处从泛化误差的视角看到了这些选择的下游后果, 依据训练成功的定量指标为等效原理提供了坚实支持.

尺度不变普适类

分析尺度不变激活函数需要使用 §5.5 的有限角结果. 特别地, 由于原点处的折点, $\langle \sigma' \sigma' \rangle$ 的 δ 展开 (10.69) 中出现的 Gaussian 期望 $\langle \sigma'' \sigma'' \rangle$ 对非线性尺度不变函数是奇异的; 我们曾承诺, 遇到这种奇异性时将回到有限角结果.

兑现这一承诺, 先回顾该节的一些内容. 首先, 按 (5.146) 分解双输入核矩阵:

$$K_{\delta_1 \delta_2}^{(\ell)} = \begin{pmatrix} K_{++}^{(\ell)} & K_{+-}^{(\ell)} \\ K_{-+}^{(\ell)} & K_{--}^{(\ell)} \end{pmatrix} = K_d^{(\ell)} \begin{pmatrix} 1 & \cos(\psi^{(\ell)}) \\ \cos(\psi^{(\ell)}) & 1 \end{pmatrix}, \quad \psi^{(\ell)} \in [0, \pi], \quad (10.82)$$

两个动力学变量是对角核 $K_d^{(\ell)}$ 与极角 $\psi^{(\ell)}$. 在此参数化下, 重印 (5.60)、(5.62)、(5.159) 与 (5.161):

$$\langle \sigma_+ \sigma_+ \rangle_{K^{(\ell)}} = \langle \sigma_- \sigma_- \rangle_{K^{(\ell)}} = A_2 K_d^{(\ell)}, \quad (10.83)$$

$$C_W \langle \sigma'_+ \sigma'_+ \rangle_{K^{(\ell)}} = C_W \langle \sigma'_- \sigma'_- \rangle_{K^{(\ell)}} = C_W A_2 \equiv \chi, \quad (10.84)$$

$$\langle \sigma_+ \sigma_- \rangle_{K^{(\ell)}} = A_2 K_d^{(\ell)} \{ \cos(\psi^{(\ell)}) + \rho [\sin(\psi^{(\ell)}) - \psi^{(\ell)} \cos(\psi^{(\ell)})] \}, \quad (10.85)$$

$$C_W \langle \sigma'_+ \sigma'_- \rangle_{K^{(\ell)}} = \chi(1 - \rho \psi^{(\ell)}), \quad (10.86)$$

其中 $A_2 \equiv (a_+^2 + a_-^2)/2$, $\rho \equiv \frac{1}{\pi} \frac{(a_+ - a_-)^2}{a_+^2 + a_-^2}$, 而 a_+, a_- 是定义具体激活函数的两个常数 (如今你应已烂熟于心).

类似地, 把冻结 NTK 分解为

$$\Theta_{\delta_1 \delta_2}^{(\ell)} = \begin{pmatrix} \Theta_{++}^{(\ell)} & \Theta_{+-}^{(\ell)} \\ \Theta_{-+}^{(\ell)} & \Theta_{--}^{(\ell)} \end{pmatrix} = \Theta_d^{(\ell)} \begin{pmatrix} 1 & \cos(\zeta^{(\ell)}) \\ \cos(\zeta^{(\ell)}) & 1 \end{pmatrix}, \quad \zeta^{(\ell)} \in [0, \pi], \quad (10.87)$$

其中 $\Theta_d^{(\ell)}$ 是对角冻结 NTK, $\zeta^{(\ell)}$ 是另一个极角.

把该分解 (10.87) 以及 (10.83)–(10.86) 代入冻结 NTK 递归 (10.67), 得到有限角参数化下的耦合递归:

$$\Theta_d^{(\ell+1)} = \chi \Theta_d^{(\ell)} + \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} A_2 K_d^{(\ell)}, \quad (10.88)$$

$$\begin{aligned} \Theta_d^{(\ell+1)} \cos(\zeta^{(\ell+1)}) &= \chi(1 - \rho \psi^{(\ell)}) \Theta_d^{(\ell)} \cos(\zeta^{(\ell)}) \\ &\quad + \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} A_2 K_d^{(\ell)} \{ \cos(\psi^{(\ell)}) + \rho [\sin(\psi^{(\ell)}) - \psi^{(\ell)} \cos(\psi^{(\ell)})] \}. \end{aligned} \quad (10.89)$$

非对角递归 (10.89) 是 $K^* = 0$ 普适类 无穷小角递归 (10.70) 的有限角对应物: 核的极角 $\psi^{(\ell)}$ 源生冻结 NTK 的有限角 $\zeta^{(\ell)}$. 换言之, 至少在角度足够小时, 核角的指数增长与衰减同冻结 NTK 角的指数增长与衰减相联系, 后者又与广义偏差-方差权衡相联系.

鉴于这一连串联系，以及本书几乎每章对类似问题的平行讨论，自然应把初始化超参数调到临界性： $\chi = 1$. 此时回顾 §5.5 的临界核解：

$$K_d^{(\ell)} = K_d^*, \quad \psi^{(\ell)} = \left(\frac{3}{\rho}\right) \frac{1}{\ell} + \dots, \quad (10.90)$$

其中 K_d^* 是由第一层设定的严格常数. 对 $K^* = 0$ 普适类讨论时已经论证过学习率等效原理，这里便依照尺度不变激活函数的等效原理 (9.94) 取训练超参数 $\lambda_b^{(\ell)} = \tilde{\lambda}_b/L$ 、 $\lambda_W^{(\ell)} = \tilde{\lambda}_W/L$. 于是

$$\Theta_d^{(\ell)} = \left(\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K_d^*\right) \frac{\ell}{L} \quad (10.91)$$

以初始条件 (9.7) 求解对角冻结 NTK 递归 (10.88). 注意这里 ℓ 指网络的特定层，而 L 是网络总深度.¹⁹³

把学习率选择、核解 (10.90) 和 NTK 解 (10.91) 代入有限角递归 (10.89)，稍加整理得

$$\cos(\zeta^{(\ell+1)}) = \left(1 - \frac{4}{\ell} + \dots\right) \cos(\zeta^{(\ell)}) + \left(\frac{1}{\ell} + \dots\right), \quad (10.92)$$

容易看出，其解是与一切参数无关的常数

$$\cos(\zeta^{(\ell)}) = \frac{1}{4} + \dots. \quad (10.93)$$

因此，对非线性尺度不变激活函数，泛化误差偏差项中的鲁棒性度量 (10.57) 是一个简单的一阶数：

$$\frac{\Theta_{-+}^{(L)}}{\Theta_{++}^{(L)}} - 1 = \cos(\zeta^{(L)}) - 1 = -\frac{3}{4} + \dots. \quad (10.94)$$

类似地，鉴于邻近输入分析可能对非线性尺度不变激活函数失效，这里也用有限角分析求泛化误差 (10.63) 的方差项. 代入核的渐近衰减 (5.167)、(5.168)，并对冻结 NTK 使用 (10.94)，得到

$$\begin{aligned} \text{Cov}\left[z_{i;-}^{(L)}(T), z_{i;-}^{(L)}(T)\right] &= K_{--} - 2 \frac{\Theta_{-+}}{\Theta_{++}} K_{-+} + \left(\frac{\Theta_{-+}}{\Theta_{++}}\right)^2 K_{++} \\ &= K_d^* [1 - \cos(\zeta^{(L)})]^2 = \frac{9}{16} K_d^* + \dots. \end{aligned} \quad (10.95)$$

不同于 $K^* = 0$ 激活函数，泛化误差的这些渐近结果 (10.94)、(10.95) 不依赖训练超参数 $\tilde{\lambda}_b, \tilde{\lambda}_W$ ，也不依赖像 δ^2 这样记录测试点与训练点间隔的常数. 不过，正如 §5.5 对 $\psi^{(\ell)}$ 的讨论，这些渐近结果开始有效的深度仍依赖 δ^2 、输入范数、激活函数和训练超参数. 尽管如此，按照临界性与等效原理正确调节超参数后，偏差与方差均为常数，从而在用非线性尺度不变激活函数训练深网络时得到最佳权衡.¹⁹⁴

¹⁹³冻结 NTK 解 (10.91) 与先前的单输入解 (9.44) 相同；这里只是按等效原理 (9.94)，用总深度重缩放偏置与权重学习率： $\lambda_b = \tilde{\lambda}_b/L$ 、 $\lambda_W = \tilde{\lambda}_W/L$.

¹⁹⁴值得注意的是精确 Bayesian 推断这一特殊情形：只有最后一层的学习率非零，以令 $\Theta^{(L)} = K^{(L)}$. 此时鲁棒性度量 (10.62) 为 $\cos(\psi^{(L)}) - 1 = O(1/\ell^2)$. 它随深度衰减，说明这种受限 Bayesian 情形显然不如使用跨层均匀学习率、经梯度下降完全训练的网络系综.

最后特别评论深线性网络. 这类网络使用 $a_+ = a_-$ 的 **linear** 激活函数, 故 $\rho = 0$. 在 §5.5 已看到, 临界点处不仅对角核保持不变, 极角也保持不变: $K_d^{(\ell)} = K_d^*$ 且 $\psi^{(\ell)} = \psi^*$. 因而冻结 NTK 的非对角递归 (10.89) 变为

$$\Theta_d^{(\ell+1)} \cos(\zeta^{(\ell+1)}) = \Theta_d^{(\ell)} \cos(\zeta^{(\ell)}) + \frac{\tilde{\lambda}_b}{L} + \frac{\tilde{\lambda}_W}{L} A_2 K_d^* \cos(\psi^*). \quad (10.96)$$

其精确解为

$$\Theta_d^{(\ell)} \cos(\zeta^{(\ell)}) = \left[\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K_d^* \cos(\psi^*) \right] \frac{(\ell-1)}{L} + \Theta_d^{(1)} \cos(\zeta^{(1)}). \quad (10.97)$$

再除以对角冻结 NTK 解 (10.91), 得到

$$\cos(\zeta^{(\ell)}) = \frac{\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K_d^* \cos(\psi^*)}{\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K_d^*} + \dots, \quad (10.98)$$

它以多项式速度渐近趋于常数. 不同于非线性尺度不变激活函数, 这个常数相当细致地依赖第一层的可观测量, 自然地把网络的泛化性质与输入联系起来. 一旦考察深线性网络内插或外推的 (无) 能力, 其真正局限便立刻显现; 下一节将对线性和非线性激活的 MLP 分析这一点.

10.3.2 内插与外推

本小节不再把重点放在成功训练的评价准则——泛化误差——上, 而更关注经训练的神经网络究竟计算什么样的函数. 这项分析使我们能够考察不同激活函数的归纳偏置, 并说明如何把这些激活函数的性质与数据集及我们试图逼近的函数的性质联系起来.

上一小节问道: 给定输入 $x_{i,+}$ 的真实输出 $y_{i,+}$, 无限宽度极限下完全训练的 MLP 对邻近输入 $x_{i,-}$ 的输出有何预测? 现在我们提高难度: 给定两个输入 $x_{i,\pm} = x_{i,0} \pm \frac{\delta x_i}{2}$ 的真实输出 $y_{i,\pm}$, 对于位于穿过 $x_{i,+}$ 与 $x_{i,-}$ 的直线上的单参数测试输入族

$$s x_{i,+} + (1-s) x_{i,-} = x_{i,0} + \frac{(2s-1)}{2} \delta x_i \equiv x_{i;(2s-1)}, \quad (10.99)$$

预测是什么? 当参数 s 位于单位区间 $s \in [0, 1]$ 内时, 这是神经网络**内插**问题; 当 s 位于单位区间外时, 这是**外推**问题. 对一般的 s , 我们把二者统称为 ***-插推**.

首先对深线性网络做一个简单的 *-插推练习, 看看使用 **linear** 激活函数的网络会做什么. 我们将具体看到, 深线性网络只能逼近一类非常有限的函数. 随后再评估光滑非线性网络.

深线性网络的线性 *-插推

要看清深线性网络如何进行 *-插推, 有一个非常简单的方法. 暂且 (也是最后一次) 回顾深线性网络的前向方程 (3.1):

$$z_{i;\alpha}^{(\ell+1)} = b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} z_{j;\alpha}^{(\ell)}, \quad (10.100)$$

其中 $z_{j;\alpha}^{(0)} \equiv x_{j;\alpha}$, 显然, 输入 (10.99) 中的线性结构会逐层保持. 也就是说, 假定第 ℓ 层的预激活具有形式

$$z_{i;(2s-1)}^{(\ell)} = sz_{i;+}^{(\ell)} + (1-s)z_{i;-}^{(\ell)} \quad (10.101)$$

从而具有这种线性结构, 则下一层中

$$\begin{aligned} z_{i;(2s-1)}^{(\ell+1)} &= b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \left[sz_{j;+}^{(\ell)} + (1-s)z_{j;-}^{(\ell)} \right] \\ &= s \left(b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} z_{j;+}^{(\ell)} \right) + (1-s) \left(b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} z_{j;-}^{(\ell)} \right) \\ &= sz_{i;+}^{(\ell+1)} + (1-s)z_{i;-}^{(\ell+1)}, \end{aligned} \quad (10.102)$$

仍然保持这种线性结构. 这不过是深线性网络计算输入的线性函数的直接结果.

因此, 对于作为两个训练点线性组合的测试输入 (10.99), 网络的输出将是这两个训练点上网络输出的线性组合:

$$z_{i;(2s-1)}^{(L)} = sz_{i;+}^{(L)} + (1-s)z_{i;-}^{(L)}. \quad (10.103)$$

这个等式在初始化时和训练结束时都成立, 意味着任意一个完全训练的深线性网络都会如下进行 *-插推:

$$z_{i;(2s-1)}^{(L)}(T) = sy_{i;+} + (1-s)y_{i;-}, \quad (10.104)$$

因为完全训练后, 网络在训练集任一元素上的输出都等于真实输出: $z_{i;\pm}^{(L)}(T) = y_{i;\pm}$. 由此可见, 完全训练的深线性网络无论如何都会线性地进行 *-插推. 这既直观又显而易见: 深线性网络执行线性变换, 所以只能计算线性函数.

当然, 这正是我们早在 §3 研究深线性网络时所说的内容. 现在, 通过展示这些网络利用训练样例作出预测的 (有限) 方式, 我们明确看到了它们在训练后为何受限. 因此, 若你试图逼近的函数是输入数据的线性函数, 深线性网络是绝佳的建模选择. 若该函数是非线性的, 就必须考虑非线性激活函数. 道理并不深奥.

光滑非线性深度网络的非线性 *-插推

要看清非线性网络做什么, 就得多下一番功夫.¹⁹⁵ 上一节看到, 完全训练网络的输出由随机核预测方程 (10.39) 给出; 为方便起见, 在此重印:

$$z_{i;\beta}^{(L)}(T) = z_{i;\beta}^{(L)} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \Theta_{\beta\tilde{\alpha}_1}^{(L)} \tilde{\Theta}_{\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)} \left(z_{i;\tilde{\alpha}_2}^{(L)} - y_{i;\tilde{\alpha}_2} \right). \quad (10.105)$$

因此, 要更一般地研究 *-插推, 需要计算测试集与训练集之间的冻结 NTK 元 $\Theta_{(2s-1)\pm}^{(L)}$, 还需要对只限于训练集的冻结 NTK 二阶子矩阵 $\tilde{\Theta}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2}$ 求逆.

¹⁹⁵要看清非线性尺度不变激活函数做什么, 还需要更多工作, 因此这里聚焦于光滑非线性激活函数. 对这类带折点的非线性尺度不变激活函数, 由于 $s \neq 0, 1$ 时 *-插推输入 $x_{i;(2s-1)}$ 与 $x_{i;\pm}$ 的范数不同, 我们需要把 §5.5 的有限角分析推广到输入范数不等的情形. 这个教学法上的挑战就留给未来的深度学习书籍作者.

后一个求逆可直接用教科书中二阶矩阵的标准逆矩阵公式完成：

$$\tilde{\Theta}^{\tilde{\alpha}_1 \tilde{\alpha}_2} = \frac{1}{\Theta_{++}\Theta_{--} - \Theta_{+-}^2} \begin{pmatrix} \Theta_{--} & -\Theta_{+-} \\ -\Theta_{+-} & \Theta_{++} \end{pmatrix}, \quad (10.106)$$

这里还用到了对称性 $\Theta_{+-} = \Theta_{-+}$ ，并且进一步省略了层指标。本节余下部分始终假定这些冻结 NTK 在输出层上取值。

接下来，要计算训练集与测试集之间的非对角元 $\Theta_{(2s-1)\pm}$ ，需要稍微推广 δ 展开。先回顾冻结 NTK 在 $\gamma^{[a]}$ 基中的分量表达式 (10.58)，再代入我们对二阶子矩阵 $\tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 作的 δ 展开 (10.59)–(10.61)，得

$$\Theta_{\pm\pm} = \Theta_{00} \pm \delta\Theta_{[1]} + (\delta\delta\Theta_{[2]} + \delta\delta\Theta_{[0]}) + O(\delta^3), \quad (10.107)$$

$$\Theta_{\pm\mp} = \Theta_{00} + (-\delta\delta\Theta_{[2]} + \delta\delta\Theta_{[0]}) + O(\delta^3), \quad (10.108)$$

这里考虑的输入对为 $x_{i;\pm} = x_{i;0} \pm \frac{\delta x_i}{2}$ 。现考虑更一般的扰动输入对

$$x_{i;\epsilon_1} \equiv x_{i;0} + \frac{\epsilon_1}{2}\delta x_i, \quad x_{i;\epsilon_2} \equiv x_{i;0} + \frac{\epsilon_2}{2}\delta x_i. \quad (10.109)$$

当 $\epsilon_{1,2}$ 取 ± 1 时，它们化为 $x_{i;\pm}$ ；而我们所关心的新情形 $\Theta_{(2s-1)\pm}$ 对应于取 $\epsilon_1 = (2s-1)$ 、 $\epsilon_2 = \pm 1$ 。对一般输入对 (10.109)， δ 展开修改为

$$\begin{aligned} \Theta_{\epsilon_1 \epsilon_2} = & \Theta_{00} + \left(\frac{\epsilon_1 + \epsilon_2}{2} \right) \delta\Theta_{[1]} + \left(\frac{\epsilon_1 + \epsilon_2}{2} \right)^2 (\delta\delta\Theta_{[2]} + \delta\delta\Theta_{[0]}) \\ & + \left(\frac{\epsilon_1 - \epsilon_2}{2} \right)^2 (-\delta\delta\Theta_{[2]} + \delta\delta\Theta_{[0]}) + O(\epsilon^3 \delta^3). \end{aligned} \quad (10.110)$$

为什么这是正确表达式？注意，(i) 每一项关于 $\epsilon_{1,2}$ 的标度都正确；(ii) 当 $\epsilon_1 = \epsilon_2 = \pm 1$ 时，正确恢复 $\Theta_{\epsilon_1 \epsilon_2} = \Theta_{\pm\pm}$ 的表达式 (10.107)；(iii) 当 $\epsilon_1 = -\epsilon_2 = \pm 1$ 时，正确恢复 $\Theta_{\epsilon_1 \epsilon_2} = \Theta_{\pm\mp}$ 的表达式 (10.108)；(iv) 该表达式在 $\epsilon_1 \leftrightarrow \epsilon_2$ 下对称。冻结 NTK 分量 $\Theta_{\epsilon_1 \epsilon_2}$ 必须满足这四个约束，而表达式 (10.110) 是满足全部约束的唯一公式。

用这个公式计算 $\Theta_{(2s-1)\pm}$ 并稍作化简，得

$$\Theta_{(2s-1)\pm} = s\Theta_{\pm\pm} + (1-s)\Theta_{\pm-} - 2s(1-s)\delta\delta\Theta_{[0]} + O(\delta^3). \quad (10.111)$$

如后文所见，至少对邻近输入而言，非线性 *-插推的关键在于 $\delta\delta\Theta_{[0]}$ 项。¹⁹⁶ 首先，由前置因子 $s(1-s)$ 可见，该项非线性地依赖测试输入。事实上，可以回头检验，对深线性网络该项恒等于零；也就是说，对这些网络，简单地有 $\Theta_{(2s-1)\pm} = s\Theta_{\pm\pm} + (1-s)\Theta_{\pm-}$ 。¹⁹⁷ 鉴于这一点，把初始预激活分解为线性和非线性部分也很有帮助：

$$z_{i;(2s-1)}^{(L)} = sz_{i;+}^{(L)} + (1-s)z_{i;-}^{(L)} + \left[z_{i;(2s-1)}^{(L)} - sz_{i;+}^{(L)} - (1-s)z_{i;-}^{(L)} \right]. \quad (10.112)$$

¹⁹⁶ 请注意， $\delta\delta\Theta_{[0]}$ 与 $\delta\delta\Theta_{[2]}$ 非常不同：前者是 $\gamma^{[0]}$ 分量 $\Theta_{[0]}$ 展开中的第二项，参见 (10.59)；后者是 $\gamma^{[2]}$ 分量 $\Theta_{[2]}$ 展开中的第一项，参见 (10.61)。

¹⁹⁷ 要快速看出这一点，注意第一层度量 (4.8) 与第一层 NTK (8.23) 都是两输入的双线性函数，而这种双线性结构在深线性网络的递归下保持： $K_{\delta_1 \delta_2}^{(\ell+1)} = C_b^{(\ell+1)} + C_W^{(\ell+1)} K_{\delta_1 \delta_2}^{(\ell)}$ ，参见 (4.118)；以及 $\Theta_{\delta_1 \delta_2}^{(\ell+1)} = \lambda_b^{(\ell+1)} + \lambda_W^{(\ell+1)} K_{\delta_1 \delta_2}^{(\ell)} + C_W^{(\ell+1)} \Theta_{\delta_1 \delta_2}^{(\ell)}$ ，参见 (9.5)。

按照 (10.103)，第二项对深线性网络消失，所以在一般情形下，它捕捉了初始化时网络输出的非线性。

把 (10.106)、(10.111) 和 (10.112) 代入核预测公式 (10.105)，可见，对测试输入 $x_{i;(2s-1)} = sx_{i;+} + (1-s)x_{i;-}$ ，完全训练后的预测为

$$\begin{aligned} & z_{i;(2s-1)}^{(L)}(T) \\ &= \left[z_{i;(2s-1)}^{(L)} - sz_{i;+}^{(L)} - (1-s)z_{i;-}^{(L)} \right] + [sy_{i;+} + (1-s)y_{i;-}] \\ &\quad - s(1-s) \left[\frac{2\delta\delta\Theta_{[0]}}{\Theta_{00}\delta\delta\Theta_{[2]} - \delta\Theta_{[1]}^2} \right] \left[2\delta\delta\Theta_{[2]} \left(z_{i;+}^{(L)} + z_{i;-}^{(L)} + y_{i;+} + y_{i;-} \right) \right. \\ &\quad \left. - \delta\Theta_{[1]} \left(z_{i;+}^{(L)} - z_{i;-}^{(L)} + y_{i;+} - y_{i;-} \right) \right] + O(\delta^3). \end{aligned} \quad (10.113)$$

与线性 *-插推公式 (10.104) 比较可见，第一项和最后一项都是新的：非线性网络可以非线性地进行 *-插推！有趣的是，非线性激活函数在完全训练后的 *-插推通过非线性量 $z_{i;(2s-1)}^{(L)} - sz_{i;+}^{(L)} - (1-s)z_{i;-}^{(L)}$ 依赖于初始化时的网络输出；相比之下，深线性网络的 *-插推只依赖训练样例的真实输出。

作为该公式的一个具体例子，考虑两个训练输入范数相同的情形。此时 $\Theta_{[1]} = 0$ ，得到简化得多的公式：

$$\begin{aligned} z_{i;(2s-1)}^{(L)}(T) &= \left[z_{i;(2s-1)}^{(L)} - sz_{i;+}^{(L)} - (1-s)z_{i;-}^{(L)} \right] + [sy_{i;+} + (1-s)y_{i;-}] \\ &\quad - 4s(1-s) \left(\frac{\delta\delta\Theta_{[0]}}{\Theta_{00}} \right) \left(z_{i;+}^{(L)} + z_{i;-}^{(L)} + y_{i;+} + y_{i;-} \right) + O(\delta^3). \end{aligned} \quad (10.114)$$

对网络系综取平均，该预测的均值为

$$m_{i;(2s-1)}^\infty = sy_{i;+} + (1-s)y_{i;-} - 4s(1-s) \left(\frac{\delta\delta\Theta_{[0]}}{\Theta_{00}} \right) (y_{i;+} + y_{i;-}) + O(\delta^3). \quad (10.115)$$

在期望下，式 (10.114) 中捕捉初始网络输出非线性的第一项消失，因此 *-插推均值的非线性完全由无量纲比值 $\delta\delta\Theta_{[0]}/\Theta_{00}$ 捕捉。

那么，完全训练的无限宽非线性神经网络究竟在计算什么样的函数？为了评估这一点，注意比值 $\delta\delta\Theta_{[0]}/\Theta_{00}$ 捕捉了训练点邻域内 *-插推的曲率。¹⁹⁸ 这种曲率编码了激活函数和架构的非普适归纳偏置，表明这类函数逼近器将如何泛化到新数据。

对给定任务和数据集，某些激活函数可能产生更合意的 *-插推类型。这可以通过泛化误差中的偏差项直接度量。代入等范数情形下的均值表达式 (10.115)，

$$\begin{aligned} m_{i;(2s-1)}^\infty - y_{i;(2s-1)} &= [y_{i;+} + (1-s)y_{i;-} - y_{i;(2s-1)}] \\ &\quad - 4s(1-s) \left(\frac{\delta\delta\Theta_{[0]}}{\Theta_{00}} \right) (y_{i;+} + y_{i;-}) + O(\delta^3), \end{aligned} \quad (10.117)$$

¹⁹⁸注意，当两个训练样本开始重合 $x_\pm \rightarrow x_0$ 时，曲率以二次速度消失， $\delta\delta\Theta_{[0]}/\Theta_{00} = O(\delta^2)$ ，而 *-插推也就越接近线性 *-插推。再把广义 δ 展开 (10.110) 应用于核，可证明 *-插推的方差在这个重合极限下消失得更快：

$$\mathbb{E} \left[z_{i;2s-1}^{(L)}(T) z_{i;2s-1}^{(L)}(T) \right] - \left(\mathbb{E} \left[z_{i;2s-1}^{(L)}(T) \right] \right)^2 = O(\delta^3). \quad (10.116)$$

可见该泛化误差偏差分解为两者的比较：真实输出的非线性——由第一个方括号给出——与网络在真实输出中点 $(y_{i,+} + y_{i,-})/2$ 附近的曲率。按这种视角，深线性网络偏好一种非常特定的归纳偏置：只计算线性函数。更一般地，我们可以（但不会在此）对任意特定激活函数计算并求解 $\delta\delta\Theta_{[0]}$ 的递归，以进一步了解采用该激活函数的深度网络所计算的函数类型。

最后注意，这项分析并未特别区分内插和外推；而且当 $s \rightarrow 0, 1$ 时，*-插推 (10.113) 以绝对确定性化为 $y_{i,\pm}$ 。事实上，在 $s = 0, 1$ 的邻域内，*-插推偏差 (10.117) 与 §10.3.1 中考虑只含一个训练样本的训练集时所见的预测偏差 (10.56) 及 (10.62) 有许多共同之处。重要的是，距离最近的训练点对测试点预测的贡献最大。

把这些结果作为思考更大训练集的指引，预测的局域性强烈暗示了一些可能的进展方向。一方面，可以通过对给定测试点附近各训练点给出的预测加权，在更复杂的预测公式上取得理论进展；只有一个邻近训练点时，可以使用 §10.3.1 的近似，有一对邻近训练点时，则使用 *-插推 (10.113)。另一方面，给定网络的归纳偏置，可以用这类分析来指导如何最佳地在数据流形上对训练输入采样，从而在训练集设计上取得实践进展。

10.4 线性模型与核方法

在离开无限宽度极限之前，先用一节把本章所做的工作置于机器学习更广阔的背景中。下一章里，这一背景将帮助我们理解有限宽度深度学习与其无限宽度对应物在性质上有哪些根本差异。

具体说来，本节将说明一种对偶的视角，用以理解由核预测公式（例如 (10.39)）描述的模型类。一方面，可以把核预测看作利用核对训练数据作 *-插推而得到的预测。另一方面，也可以把它看作某个经过训练、关于参数呈线性的模型的输出。前一种视角对我们更自然，因为我们始终考虑模型参数上的系综，然后把参数积分掉。因此，先从后一种线性模型视角讲起。¹⁹⁹

10.4.1 线性模型

最简单的线性模型——也许也是最简单的机器学习模型——就是一个单层（即零隐藏层）网络

$$z_i(x_\delta; \theta) = b_i + \sum_{j=1}^{n_0} W_{ij} x_{j;\delta}. \quad (10.118)$$

这一模型关于参数 $\theta = \{b_i, W_{ij}\}$ 和输入 $x_{j;\delta}$ 都是线性的，但线性模型一词中的线性得名于模型对参数 θ 而非输入 x 的依赖。特别地，尽管输入样本的分量 $x_{j;\delta}$ 有时能充当函数逼近的一组合理特征，但一般并非如此。事实上，考虑到我们在深度学习背景下已经用了大量篇幅讨论表征群流和表征学习，自然可以预期：输入数据在用于任何机器学习任务之前都需要经过（预）处理。

¹⁹⁹梯度下降训练的无限宽网络与核方法之间的联系，是在引入 NTK 的背景下由文献 [57] 指出的。随后，文献 [62] 对把这类网络视作线性模型作了更深入的讨论。

解决这一问题的一种传统方法继承自统计学，即设计更好的特征。在计算机能力较弱、模型必须简单得多才能优化的年代，这种方法是必要的。例如，除了特征 x_j ，让模型考虑特征 $x_j x_k$ 也许会有帮助，因为它使我们能够考虑一个分量对另一个分量的依赖。更一般地，可以设计一组固定的**特征函数** $\phi_j(x)$ ，期望它们适合数据集 $\mathcal{D}$ 和当前的底层任务。²⁰⁰

在这种传统方法中，我们希望所有复杂的建模工作都集中在构造这些特征函数 $\phi_j(x)$ 上；若做得足够好，那么与之关联的**线性模型**

$$z_i(x_\delta; \theta) = b_i + \sum_{j=1}^{n_f} W_{ij} \phi_j(x_\delta) = \sum_{j=0}^{n_f} W_{ij} \phi_j(x_\delta), \quad (10.119)$$

就易于训练、易于解释，并且能在目标任务上表现良好。这里遵循一种惯常的记号简化：令 $\phi_0(x) \equiv 1$ 和 $W_{i0} \equiv b_i$ ，把偏置向量并入权重矩阵。因此，线性模型的输出 $z_i(x; \theta)$ 线性地依赖模型参数 θ ；这些参数构成一个维数为 $n_{\text{out}} \times (n_f + 1)$ 的合并权重矩阵 W_{ij} 。仍可把这个模型视作单层神经网络，只不过此时每个输入在送入网络之前都先经过函数 $\phi_j(x)$ 预处理。

现在说明：给定训练集 $\mathcal{A}$ ，如何学习权重矩阵的最优值 W_{ij}^* 。最常用的方法是最小化 MSE 损失

$$\mathcal{L}_A(\theta) = \frac{1}{2} \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{i=1}^{n_{\text{out}}} [y_{i;\tilde{\alpha}} - z_i(x_{\tilde{\alpha}}; \theta)]^2 = \frac{1}{2} \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{i=1}^{n_{\text{out}}} \left[y_{i;\tilde{\alpha}} - \sum_{j=0}^{n_f} W_{ij} \phi_j(x_{\tilde{\alpha}}) \right]^2. \quad (10.120)$$

使用线性模型的监督学习称为**线性回归**；由于线性模型的 MSE 损失关于模型参数必然是二次的，这又是一个可解析求解的学习问题 (7.7)。对参数求 $\mathcal{L}_A$ 的导数并令其为零，得到决定最优权重矩阵 W_{ij}^* 的隐式方程：

$$\sum_{k=0}^{n_f} W_{ik}^* \left[\sum_{\tilde{\alpha} \in \mathcal{A}} \phi_k(x_{\tilde{\alpha}}) \phi_j(x_{\tilde{\alpha}}) \right] = \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \phi_j(x_{\tilde{\alpha}}). \quad (10.121)$$

为求解该方程，定义一个对称的 $(n_f + 1) \times (n_f + 1)$ 特征矩阵

$$M_{ij} \equiv \sum_{\tilde{\alpha} \in \mathcal{A}} \phi_i(x_{\tilde{\alpha}}) \phi_j(x_{\tilde{\alpha}}), \quad (10.122)$$

其矩阵元给出在所有训练样本 $\tilde{\alpha} \in \mathcal{A}$ 上求和的特征函数两两聚合。然后，把它的逆作用于隐式表达式 (10.121) 两边，得到解

$$W_{ij}^* = \sum_{k=0}^{n_f} \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \phi_k(x_{\tilde{\alpha}}) (M^{-1})_{kj}. \quad (10.123)$$

²⁰⁰如果输入 x 是某种抽象对象——例如文本文档——这类特征函数同样有用；此时输入必须先转换成数值向量，才能由参数化模型处理。

注意, 这个解依赖于训练集: 它线性地依赖真实函数值 $y_{i;\tilde{\alpha}}$, 而对输入特征 $\phi_k(x_{\tilde{\alpha}})$ 的依赖则更为复杂.²⁰¹

最后, 可以用这个完全训练的线性模型及其最优参数 W_{ij}^* 对新的测试集输入 $x_{\tilde{\beta}}$ 作出预测:

$$z_i(x_{\tilde{\beta}}; \theta^*) = \sum_{j=0}^{n_f} W_{ij}^* \phi_j(x_{\tilde{\beta}}), \quad (10.125)$$

由此得到线性回归问题的闭式解. 重要的是, 学习完成后, 只需存储最优参数 W_{ij}^* , 便可以忘掉训练数据.

10.4.2 核方法

尽管上述内容都很简单, 但本书通常不显式处理参数, 所以这种表述对我们不太熟悉. 为把线性模型改写成更熟悉的形式, 考虑解的一个对偶表达式. 首先, 把最优参数 W_{ij}^* 的表达式 (10.123) 代入线性回归解 (10.125), 得到

$$z_i(x_{\tilde{\beta}}; \theta^*) = \sum_{\tilde{\alpha} \in \mathcal{A}} \left[\sum_{j,k=0}^{n_f} \phi_j(x_{\tilde{\beta}}) (M^{-1})_{jk} \phi_k(x_{\tilde{\alpha}}) \right] y_{i;\tilde{\alpha}}. \quad (10.126)$$

注意, 方括号内的表达式涉及 $(n_f + 1) \times (n_f + 1)$ 维矩阵 M_{ij} 的求逆; 得到最优参数 W_{ij}^* 时正需要这个逆. 当特征数较少时, 这样做很合适; 但若定义的特征函数数目非常大, 即 $n_f \gg 1$, 表示并求逆这样一个矩阵在计算上可能很困难.

不过, 事实证明我们根本不必做这些事情. 为看清原因, 引入一个新的 $N_{\mathcal{D}} \times N_{\mathcal{D}}$ 维对称矩阵:

$$k_{\delta_1 \delta_2} \equiv k(x_{\delta_1}, x_{\delta_2}) \equiv \sum_{i=0}^{n_f} \phi_i(x_{\delta_1}) \phi_i(x_{\delta_2}). \quad (10.127)$$

作为特征函数的内积, $k_{\delta_1 \delta_2}$ 度量两个输入 $x_{i;\delta_1}$ 和 $x_{i;\delta_2}$ 在特征空间中的相似性. 这种相似性度量称为核.²⁰²

²⁰¹ 若特征数 $(n_f + 1)$ 大于训练集大小 $N_{\mathcal{A}}$, 模型就是过参数化的, 而 M_{ij} 不具有唯一的逆. 指定解的一种方案, 是在损失 (10.120) 中加入形如 $a \sum_{ij} W_{ij}^2$ 的正则化项; 关于无限宽网络正则化的相关讨论, 参见 §10.2.4 的脚注 178. 在修改后的回归问题中, 可以对正则化矩阵

$$M_{ij} = 2a \delta_{ij} + \sum_{\tilde{\alpha} \in \mathcal{A}} \phi_i(x_{\tilde{\alpha}}) \phi_j(x_{\tilde{\alpha}}), \quad (10.124)$$

求逆, 并在计算结束时令调节参数趋于零, 即 $a \rightarrow 0^+$. 注意, 无论是保持调节参数 a 有限, 还是处于 $(n_f + 1) < N_{\mathcal{A}}$ 的欠参数化区域, 线性模型即使得到完全优化, 也不再能达到零训练损失.

²⁰² 例如, 对最简单的线性模型 (10.118), 核就是两个输入的内积

$$k_{\delta_1 \delta_2} \equiv \sum_{i=1}^{n_0} x_{i;\delta_1} x_{i;\delta_2}, \quad (10.128)$$

它通常称为线性核.

采用一种应当十分熟悉的记号, 用波浪号把核在训练集上取值所得的 $N_A \times N_A$ 维子矩阵记为 $\tilde{k}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$. 于是可以把它逆写成 $\tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 满足

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{k}_{\tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{\tilde{\alpha}_1 \tilde{\alpha}_3}^{\tilde{\alpha}_1}. \quad (10.129)$$

注意, 由核的定义 (10.127) 可知, 要使这个逆存在并令该方程成立, 必须处于 $(n_f + 1) \geq N_A$ 的过参数化区域.

现在考察如何重排解 (10.126) 中方括号内的因子. 将它乘以子矩阵 $\tilde{k}_{\tilde{\alpha} \tilde{\alpha}_1}$, 可以把该因子化简为

$$\begin{aligned} & \sum_{\tilde{\alpha} \in \mathcal{A}} \left[\sum_{j,k=0}^{n_f} \phi_j(x_{\dot{\beta}}) (M^{-1})_{jk} \phi_k(x_{\tilde{\alpha}}) \right] \tilde{k}_{\tilde{\alpha} \tilde{\alpha}_1} \\ &= \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{j,k=0}^{n_f} \phi_j(x_{\dot{\beta}}) (M^{-1})_{jk} \phi_k(x_{\tilde{\alpha}}) \sum_{i=0}^{n_f} \phi_i(x_{\tilde{\alpha}}) \phi_i(x_{\tilde{\alpha}_1}) \\ &= \sum_{i,j,k=0}^{n_f} \phi_j(x_{\dot{\beta}}) (M^{-1})_{jk} M_{ki} \phi_i(x_{\tilde{\alpha}_1}) \\ &= \sum_{i=0}^{n_f} \phi_i(x_{\dot{\beta}}) \phi_i(x_{\tilde{\alpha}_1}) = k_{\dot{\beta} \tilde{\alpha}_1}. \end{aligned} \quad (10.130)$$

这里, 第二行使用核的定义 (10.127), 第三行使用特征矩阵的定义 (10.122) 对 $\tilde{\alpha}$ 求和; 最后一行再次使用核的定义. 最后, 把第一行和最后一行的表达式乘以逆子矩阵 $\tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 得到方括号内因子的新表示

$$\left[\sum_{j,k=0}^{n_f} \phi_j(x_{\dot{\beta}}) (M^{-1})_{jk} \phi_k(x_{\tilde{\alpha}_2}) \right] = \sum_{\tilde{\alpha}_1 \in \mathcal{A}} k_{\dot{\beta} \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2}, \quad (10.131)$$

从而可以把线性模型预测 (10.125) 改写为

$$z_i(x_{\dot{\beta}}; \theta^*) = \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{\dot{\beta} \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2}. \quad (10.132)$$

以这种方式计算线性模型预测时, 所得方法称为核机或**核方法**.

注意, 在解的这个对偶表达式中, 最优参数 W_{ij}^* 和特征函数 $\phi_i(x)$ 都不出现. 因此, 我们成功地把特征空间量——一个 $(n_f + 1)$ 维特征向量和一个 $(n_f + 1) \times (n_f + 1)$ 维矩阵的逆——换成了样本空间量——一个 N_A 维向量 $k_{\dot{\beta} \tilde{\alpha}_1}$ 和一个 $N_A \times N_A$ 维矩阵 $\tilde{k}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的逆.²⁰³ 之所以可行, 是因为在解 (10.132) 中, 我们真正关心的只有特征函数的内积——也就是核——而非特征本身的取值.

²⁰³在某些情形下, 指定并计算核远比指定并计算特征函数简单. 例如, *Gaussian* 核定义为

$$k_{\delta_1 \delta_2} \equiv \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^{n_0} (x_{i; \delta_1} - x_{i; \delta_2})^2 \right], \quad (10.133)$$

它蕴含一个无限维特征空间, 但只需计算 n_{in} 维输入向量之间的平方距离, 再对结果取指数, 就能求出核值. (要看出 *Gaussian* 核为何蕴含无穷多个特征函数, 可以把平方距离写成三个内积之和, 再关于这些内

用 (10.132) 把线性模型预测写成核的形式后, 可以把预测理解为同以往所见样例的直接比较. 具体而言, 该解用 $k_{\hat{\beta}\hat{\alpha}_1}$ 计算新测试输入 $x_{\hat{\beta}}$ 与所有训练样例的相似性, 再利用这种相似性和样本空间度量 $\hat{k}^{\hat{\alpha}_1\hat{\alpha}_2}$, 对训练集的真实函数值 $y_{i;\hat{\alpha}_2}$ 作线性加权. 因此, 核方法有时称为基于记忆的方法, 因为它们需要记住整个训练集.²⁰⁴ 这应与参数化线性模型解 (10.125) 对比; 在后者中, 我们忘掉训练集样本, 只显式存储最优参数值 W_{ij}^* .

最后注意, 预测中不存在连线: 预测的 z_i 分量完全由训练样例的 y_i 分量决定. 这在线性模型解 (10.125) 的最优权重矩阵 W_{ij}^* (10.123) 中只是隐含的, 但在核方法解 (10.132) 中则是显式的. 这是这类线性模型与核方法作为机器学习模型受到限制的诸多表现之一.

10.4.3 作为线性模型的无限宽度网络

核方法的预测公式 (10.132) 想必让你感到格外熟悉: 若把核方法的核 $k_{\delta_1\delta_2}$ 与 Bayesian 核 $K_{\delta_1\delta_2}^{(L)}$ 对应起来, 它就与精确 Bayesian 均值预测 (6.64) 完全相同; 若把核方法的核 $k_{\delta_1\delta_2}$ 与冻结神经正切核 $\Theta_{\delta_1\delta_2}^{(L)}$ 对应起来, 它也与 (神经正切) 核均值预测 (10.40) 完全相同.²⁰⁵ 这终于说明了这些对象以及本章名称的由来.

事实上, 一边是这些传统线性模型和核方法, 另一边是无限宽度模型的 (神经正切) 核学习, 二者之间存在十分直接的联系. 先讨论较简单的 Bayesian 核情形. 正如 §10.2.4 所指出的, 这一选择对应于只把输出层偏置 $b_i^{(L)}$ 和权重 $W_{ij}^{(L)}$ 视为可训练模型参数, 因此初始化时的网络输出为

$$z_i^{(L)}(x_{\delta}; \theta) = b_i^{(L)} + \sum_{j=1}^{n_{L-1}} W_{ij}^{(L)} \sigma_{j;\delta}^{(L-1)} = \sum_{j=0}^{n_{L-1}} W_{ij}^{(L)} \sigma_{j;\delta}^{(L-1)}, \quad (10.134)$$

其中, 右边定义了 $\sigma_{0;\delta}^{(L-1)} \equiv 1$ 和 $W_{i0}^{(L)} \equiv b_i^{(L)}$. 它与线性模型 (10.119) 几乎相同, 区别只在于特征函数是随机的: $\hat{\phi}_{j;\delta} \equiv \sigma_{j;\delta}^{(L-1)}$. 特别地, 这里给特征函数加上帽子, 是为了强调它们依赖隐藏层参数; 这些参数在开始时从初始化分布中采样, 随后便固定下来. 这有时称为**随机特征模型**.

积对指数函数作 Taylor 展开; Taylor 展开中的各项便给出特征函数.) 由此可见, 计算核可能远比显式表示特征容易.

事实上, 任何基于线性核 (10.128) 的算法, 都可以通过把简单核换成 Gaussian 核 (10.133) 之类的复杂核而推广. 这称为**核技巧**; 它用核方法的语言描述了我们如何把最简单的线性模型 (10.118)——关于输入是线性的——推广到更一般的线性模型 (10.119)——关于输入是非线性的.

²⁰⁴通常, 要使某种特定核方法在计算上可行, 模型预测会在局域范围内作出, 主要纳入最接近目标测试样本的训练样本信息. 鉴于上一节的 *-插推结果, 不难想象如何让这类方法取得良好效果.

这种局域方法的一个典型例子是 k -最近邻 [63, 64], 它是核方法的一种特殊类型. 由于只考虑邻近训练点, 这类局域算法可以避免我们为精确 Bayesian 推断预测和冻结 NTK 预测指出的一些不切实际之处. 把这类局域算法推广到 §6.4 讨论的有限宽精确 Bayesian 推断, 或推广到将在 §∞ 讨论的有限宽、基于梯度的学习预测, 会很有意思.

²⁰⁵你或许已经注意到, 我们的随机 (神经正切) 核预测公式 (10.39) 还依赖初始化时的网络输出, 并具有非零协方差. 这与脚注 201 中的讨论有关: 在过参数化区域 $(n_f + 1) > N_A$ 中, 尤其当特征数为无穷时, $(n_f + 1) \times (n_f + 1)$ 维矩阵 $M_{ij} \equiv \sum_{\bar{\alpha} \in A} \phi_i(x_{\bar{\alpha}}) \phi_j(x_{\bar{\alpha}})$ (10.122) 没有唯一的逆. 因而在这一区域, 最优权重矩阵 W^* 并不唯一: 若不使用正则化技巧 (10.124) 唯一选出其中一个解, 对偶核描述中的预测就会依赖模型的初始化.

此时，核方法意义下的核也是随机的：

$$\begin{aligned}\widehat{k}_{\delta_1\delta_2} &= C_b^{(L)} \widehat{\phi}_{0;\delta_1} \widehat{\phi}_{0;\delta_2} + \frac{C_W^{(L)}}{n_{L-1}} \sum_{j=1}^{n_{L-1}} \widehat{\phi}_{j;\delta_1} \widehat{\phi}_{j;\delta_2} \\ &= C_b^{(L)} + C_W^{(L)} \left(\frac{1}{n_{L-1}} \sum_{j=1}^{n_{L-1}} \sigma_{j;\delta_1}^{(L-1)} \sigma_{j;\delta_2}^{(L-1)} \right),\end{aligned}\quad (10.135)$$

其中，第一行对核定义 (10.127) 中特征求和的各项重新赋予了权重 $C_b^{(L)}$ 和 $C_W^{(L)}/n_L$.²⁰⁶ 注意，在研究预激活量的 RG 流时，我们把对象 (10.135) 称为随机度量 (4.70). 现在对初始化系综取期望，在无限宽度极限下有

$$\mathbb{E} \left[\widehat{k}_{\delta_1\delta_2} \right] = C_b^{(L)} + C_W^{(L)} \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(L-1)}} = K_{\delta_1\delta_2}^{(L)}, \quad (10.137)$$

最后一个等号使用了核递推 (10.44).²⁰⁷ 由此可见，无限宽度下的精确 Bayesian 推断可以理解为一个关于固定随机特征的简单线性模型 (10.134).

现在为无限宽度下基于梯度的学习给出线性模型解释. 由于线性模型关于其参数是线性的，可以更一般地把**随机特征**定义为

$$\widehat{\phi}_{i,\mu}(x_\delta) \equiv \frac{dz_{i;\delta}^{(L)}}{d\theta_\mu}. \quad (10.138)$$

明确地说，这个导数在初始化时求值，因此这些特征在无限宽度极限下固定不变. 对 MLP 而言，随机特征显式为

$$\widehat{\phi}_{i,W_{k_1k_2}^{(\ell)}}(x_\delta) = \left(\sum_{j_{L-1}, \dots, j_{\ell+1}} W_{ij_{L-1}}^{(L)} \sigma_{j_{L-1};\delta}^{(L-1)} \cdots W_{j_{\ell+1}k_1}^{(\ell+1)} \sigma_{k_1;\delta}^{(\ell)} \right) \sigma_{k_2;\delta}^{(\ell-1)}, \quad (10.139)$$

偏置分量则由 $\sigma_{0;\delta}^{(\ell)} \equiv 1$ 和 $W_{k0}^{(\ell)} \equiv b_k^{(\ell)}$ 给出. 从这个表达式可以直接看出，这些特征是随机的，依赖初始化时偏置和权重的具体取值. 还要注意，Bayesian 线性模型 (10.134) 只使用这些特征的一个子集 $\widehat{\phi}_{i,W_{ij}^{(L)}} = \sigma_{j;\delta}^{(L-1)}$ ，因而它受到更多限制，表达能力也弱得多.

进一步注意，这些特征函数 $\widehat{\phi}_{i,\mu}(x_\delta)$ 与 §4.6 讨论表征群流时给出的特征概念有关，但并不完全相同. 在那里，第 ℓ 层特征对应第 ℓ 层预激活量 $z_{i;\delta}^{(\ell)}$ 或激活量 $\sigma_{i;\delta}^{(\ell)}$. 然而这里的随机特征函数 (10.139) 正比于第 $(\ell-1)$ 层激活量 $\sigma_{i;\delta}^{(\ell-1)}$ ，同时还乘有来自更深层的对象.²⁰⁸

²⁰⁶ 核方法的核 (10.127) 还可作更一般的定义，对每对特征函数的贡献赋权：

$$k_{\delta_1\delta_2} \equiv \sum_{i,j=0}^{n_f} c_{ij} \phi_i(x_{\delta_1}) \phi_j(x_{\delta_2}). \quad (10.136)$$

²⁰⁷ 也可以由中心极限定理看出：在无限宽度极限下，即使不显式对初始化取平均，随机核 $\widehat{k}_{\delta_1\delta_2}$ 也会等于核 $K_{\delta_1\delta_2}^{(L)}$. 核的这种自平均等价于连通四点相关函数在无限宽度下消失. 在这里还可以把核的自平均理解为对无穷多个随机特征求和的结果.

²⁰⁸ 此后提到网络的特征时，我们是指核方法意义下的特征函数 $\widehat{\phi}_{i,\mu}(x_\delta)$ ，而不是激活量 $\sigma_i^{(\ell)}(x_\delta)$. 相应地，此后将用表征学习描述这类特征函数如何在训练过程中形成数据依赖性.

显然，与这些特征相联系的随机核为

$$\widehat{k}_{ij;\delta_1\delta_2} \equiv \sum_{\mu,\nu} \lambda_{\mu\nu} \widehat{\phi}_{i,\mu}(x_{\delta_1}) \widehat{\phi}_{j,\nu}(x_{\delta_2}) = \sum_{\mu,\nu} \lambda_{\mu\nu} \frac{dz_{i;\delta_1}^{(L)}}{d\theta_\mu} \frac{dz_{j;\delta_2}^{(L)}}{d\theta_\nu} \equiv \widehat{H}_{ij;\delta_1\delta_2}^{(L)}, \quad (10.140)$$

它正是第 L 层随机 NTK (8.5).²⁰⁹ 这里利用核方法之核的更一般定义 (10.136)，把学习率张量 $\lambda_{\mu\nu}$ 纳入表达式。相应地，在无限宽度下，NTK 冻结且关于末层神经元指标对角，从而

$$k_{\delta_1\delta_2} \equiv \sum_{\mu,\nu} \lambda_{\mu\nu} \widehat{\phi}_{i,\mu}(x_{\delta_1}) \widehat{\phi}_{i,\nu}(x_{\delta_2}) = \sum_{\mu,\nu} \lambda_{\mu\nu} \frac{dz_{i;\delta_1}^{(L)}}{d\theta_\mu} \frac{dz_{i;\delta_2}^{(L)}}{d\theta_\nu} \equiv \Theta_{\delta_1\delta_2}^{(L)}. \quad (10.141)$$

由此可见，在无限宽度下，完全训练网络的平均输出不过是基于随机特征 (10.138) 的线性模型。从这个意义上说，无论无限宽度神经网络看起来多深，就模型复杂度而言，它们都相当浅。

回头看本节开头讨论的线性模型，我们必须引入特征函数 $\phi_i(x)$ ，利用对手头任务和数据的认识来设计它们，从而对输入作（预）处理。这样一来，需要学习的参数化模型本身就很简单，即它是线性的。²¹⁰ 随后，我们又用相应的核重新解释这个拟合好的线性模型；该核本身可以自然地理解为度量所设计特征之间的相似性。

然而，对于无限宽度网络，我们并未设计冻结 NTK，它所对应的特征也是随机的。网络由架构、超参数、偏置和权重定义，而从这些变量到 NTK 与核预测之间铺满了计算。因此，把实际神经网络抽象掉，似乎是一种非常奇怪的核设计方式。

事实上，我们刚刚了解到，无限宽度神经网络只能作关于训练集真实输出线性的预测；它们是只能计算随机特征线性组合的线性模型。当然，深度学习之所以令人兴奋，是因为它能解决经典机器学习方法失败的问题；当我们不知道如何设计特征函数或核，或者这种设计过于复杂时，它依然有效。神经网络若要超越核方法，就必须能从数据中学习有用特征，而不能只利用随机特征的复杂线性组合。因此，要使特征函数 (10.138) 在训练中演化——也就是要实现表征学习——就必须超越核方法。

所幸，有限宽度网络并不是核方法。现在请翻到下一章，看看它们究竟是什么。

²⁰⁹ 不过务必注意，在有限宽度下，随机神经正切核 $\widehat{k}_{ij;\delta_1\delta_2} = \widehat{H}_{ij;\delta_1\delta_2}^{(L)}$ 在训练期间并不固定——它会从数据中学习有用特征，并随初始化而随机变化；因此，尽管名为核，它实际上并不是核。

²¹⁰ 请不要混淆这里讨论的线性模型与 §10.3.2 中线性函数和非线性函数的区别。

线性模型是关于模型参数线性的模型 (10.119)，并具有关于训练集 $\mathcal{A}$ 中真实输出 $y_{i;\tilde{\alpha}}$ 线性的对偶核描述 (10.132)；正如已经看到的，线性模型非常简单，容易解析求解。由定义 (10.119) 可知，对一般非线性特征函数 $\phi_i(x)$ ，线性模型通常关于输入 x 是非线性的。因而线性模型可以计算输入的非线性函数。我们在 (10.113) 中求解光滑非线性网络的非线性 *-插推时，已经显式看到这一点。

与此不同，深线性网络是使用 `linear` 激活函数的神经网络。这类网络计算输入的线性函数，因此只能在训练点之间作线性 *-插推，参见 (10.104)。然而，由于它们（当 $L > 1$ 时）不是线性模型，所计算的函数非线性地依赖模型参数。所以，它们的训练动力学可能相当复杂；在有限宽度下，它们甚至会展现表征学习。

第 11 章

表征学习

几乎不可否认，一切理论的最高目标，是使不可约的基本要素尽可能简单、尽可能少，同时又不牺牲对任何一项经验材料的恰当表征。

Albert Einstein, 出自 1933 年演讲 “On the Method of Theoretical Physics” [65].

上一章中，我们了解到，线性模型无法从数据中学习特征。因而，无限宽度极限过于简单，不足以恰当地表征深度学习；若要纳入其不可约的基本要素——表征学习——研究有限宽度网络在定性上至关重要。

本章前半部分将把网络输出的梯度下降更新关于全局学习率 η 的 Taylor 展开推进到二阶，以分析其领先修正。随后还会看到，NTK 更新关于 η 的一阶 Taylor 展开中会出现类似贡献，并说明这一修正是一种有限宽度效应。NTK 由固定变为动态，表明对于有限宽度网络，构成 NTK 的特征函数本身会在训练过程中从数据中学习。

遗憾的是，动力学中完整的 $O(1/n)$ 贡献还包括网络输出更新关于全局学习率 η 展开到三阶所产生的项，以及 NTK 更新关于 η 展开到二阶所产生的类似项。若要实际计算完全训练的有限宽度网络之分布，纳入这些贡献是必要的；但若只想定性研究这类模型中表征学习的机制，将网络输出展开到 $O(\eta^2)$ 、将 NTK 展开到 $O(\eta)$ 就已足够。

考虑到这一点，为了把表征学习的教学性内容与真实 MLP 中纷繁的唯象细节分开，本章后半部分将集中研究一个等价于这种 $O(\eta^2)$ 截断的简化模型，它给出表征学习的最小定性图景。我们讨论的这些最小模型构成一类有效且可能有用的机器学习模型，能够实现表征学习；但颇为麻烦的是，有限宽度 MLP 并不属于这一类。认真听取真实 MLP 的意见之后，下一整章 (§∞) 将完整而细致地推导它们的 $O(1/n)$ 训练动力学。

首先，在 §11.1 中，我们将求出预激活量更新中关于 η 的二阶贡献，以及 NTK 更新中关于 η 的一阶贡献。这使我们能够把所有表征学习都追溯到一个不可约的基本要素，即神经正切核的微分 (dNTK)：正如 NTK 支配预激活量动力学关于 η 的领先阶，dNTK 支配 NTK 动力学关于 η 的领先阶。

把 dNTK 确认为表征学习的驱动力之后，我们将在 §11.2 中递归确定它与预激活量的相关性如何依赖网络层 ℓ 。具体而言，先推导 dNTK 的随机前向方程，再计算确定初始化时预激活量–NTK–dNTK 联合分布统计量所需的其余递推。因此，这一节与 §4 和 §8 中的 RG 流分析具有平行结构。重要的是，我们将看到，所有涉及 dNTK 的统计量都是 $O(1/n)$ ，所以只在有限宽度下有贡献。

在 §11.3 中，我们将运用临界性与普适性原理分析新的 dNTK 递推。所有超参数都已经由预激活量 (§5) 和 NTK (§9) 的平行分析固定；前者固定初始化超参数，后者固

定训练超参数. 因此, 这里关注的是在这些超参数固定时, dNTK 统计量关于深度和宽度的标度. 不难猜到, 在两个普适类 (§11.3.1 与 §11.3.2) 中, dNTK 的效应——因而表征学习的一种来源——都正比于有效理论截断, 即深宽比 L/n .

至此, 我们已经确立 NTK 会在有限宽度下演化, 并求出了其动力学的一项重要贡献. 接下来在 §11.4 中, 我们将稍稍后退一步, 仿照 §10.4 对无限宽度网络的讨论寻找更广阔的背景. 为此, 在 §11.4.1 中将引入一类非线性模型, 尤其关注二次模型, 从而对机器学习的传统主力——线性模型——作最小扩展. 这一二次模型给出表征学习的一个最小模型, 完全不依赖神经网络抽象. 此外, 这类模型简单且完全可解, 却仍能捕捉表征学习的本质.

求解由此得到的近线性二次回归问题后, 我们将会在 §11.4.2 中进一步给出二次模型解的对偶描述, 并称之为近核方法. 这使我们能在该最小设定中辨认出与 dNTK 对应的对象, 并说明如何利用一个从数据中学习的已训练核对测试集作预测. 总体而言, 我们希望这一框架作为一类能够学习表征的新型近简单机器学习模型, 具有进一步的理论与实践价值.

此时, 近核方法与有限宽度网络之间的联系——至少在 η^2 阶——将近乎显然; 我们会在 §11.4.3 中把它完全明确化. 这样便能准确理解深度学习何以是表征学习的一个非最小模型. 最终将得出结论: 深度学习的力量在于深度——由逐层 RG 流诱导的网络架构归纳偏置——它为学习提供了一组特别好的初始特征. 这些观察将大大帮助我们解释下一章略显纷繁的有限宽度解.

11.1 神经正切核的微分

回顾在梯度下降的第一步中, 任意特定网络第 ℓ 层参数的变化由 (7.11) 给出:

$$\vec{d}\theta_{\mu}^{(\ell)} \equiv \theta_{\mu}^{(\ell)}(t=1) - \theta_{\mu}^{(\ell)}(t=0) = -\eta \sum_{\nu} \lambda_{\mu\nu}^{(\ell)} \left(\sum_{k=1}^{n_L} \sum_{\tilde{\alpha} \in \mathcal{A}} \frac{\partial \mathcal{L}_{\mathcal{A}}}{\partial z_{k;\tilde{\alpha}}^{(L)}} \frac{dz_{k;\tilde{\alpha}}^{(L)}}{d\theta_{\nu}^{(\ell)}} \right). \quad (11.1)$$

本节中, 明确标出每个参数来自哪一层会很有帮助. 这里, $\theta_{\mu}^{(\ell)}$ 表示第 ℓ 层偏置 $\theta_{\mu}^{(\ell)} \equiv b_i^{(\ell)}$ 或第 ℓ 层权重 $\theta_{\mu}^{(\ell)} \equiv W_{ij}^{(\ell)}$; 第 ℓ 层模型参数指标 μ, ν 只遍历第 ℓ 层偏置向量 $b_i^{(\ell)}$ 和权重矩阵 $W_{ij}^{(\ell)}$ 的所有分量. 此外, 为强调学习率张量 $\lambda_{\mu\nu}^{(\ell)}$ 只连接同一层 ℓ 内的参数, 我们为清楚起见给它加上层指标. 暂时允许 $\lambda_{\mu\nu}^{(\ell)}$ 在一层内任意作用, 不过最终关心的是它为对角的情形; 和往常一样, 每层有两个训练超参数 $\lambda_b^{(\ell)}$ 和 $\lambda_W^{(\ell)}$.

再提醒一次, 没有显式步数参数的量都在初始化时求值——有时也会显式写出 $t=0$ 以特别强调. 样本指标记号仍是: 训练集输入用带波浪号的 alpha, $\tilde{\alpha} \in \mathcal{A}$; 测试集输入用带点的 beta, $\dot{\beta} \in \mathcal{B}$; 可能属于任一集合的输入则用不带修饰的 delta, $\delta \in \mathcal{D} = \mathcal{A} \cup \mathcal{B}$.

现在, 为了超越无限宽度极限, 需要把第 ℓ 层预激活量的变化关于参数更新展开到二阶:

$$\begin{aligned} \vec{d}z_{i;\delta}^{(\ell)} &\equiv z_{i;\delta}^{(\ell)}(t=1) - z_{i;\delta}^{(\ell)}(t=0) \\ &= \sum_{\ell_1=1}^{\ell} \sum_{\mu} \frac{dz_{i;\delta}^{(\ell)}}{d\theta_{\mu}^{(\ell_1)}} \vec{d}\theta_{\mu}^{(\ell_1)} + \frac{1}{2} \sum_{\ell_1, \ell_2=1}^{\ell} \sum_{\mu_1, \mu_2} \frac{d^2 z_{i;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \vec{d}\theta_{\mu_1}^{(\ell_1)} \vec{d}\theta_{\mu_2}^{(\ell_2)} + \dots \end{aligned} \quad (11.2)$$

注意，第 ℓ 层预激活量 $z_{i;\delta}^{(\ell)}$ 不可能依赖比第 ℓ 层更深的层 ℓ' 中的模型参数 $\theta_\mu^{(\ell')}$ 。因而是当 $\ell' > \ell$ 时， $dz_{i;\delta}^{(\ell)}/d\theta_\mu^{(\ell')} = 0$ ，所以上式中的层求和在 ℓ 处截断。

接下来，要略微改写参数更新方程 (11.1)，针对的是预激活量展开 (11.2) 中出现的参数 $\theta_\mu^{(\ell_a)}$ ，也就是所有有贡献的 $\ell_a \leq \ell$ 层参数。为此，利用链式法则，把输出层预激活量 $z_{k;\tilde{\alpha}}^{(L)}$ 关于第 ℓ_a 层模型参数的导数分解为

$$\frac{dz_{k;\tilde{\alpha}}^{(L)}}{d\theta_\nu^{(\ell_a)}} = \sum_j \frac{dz_{k;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(\ell)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_\nu^{(\ell_a)}}, \quad (11.3)$$

其中中间层 ℓ 满足 $\ell_a \leq \ell$ 。利用这一分解，可把参数更新 (11.1) 改写为

$$d\theta_\mu^{(\ell_a)} = -\eta \sum_\nu \lambda_{\mu\nu}^{(\ell_a)} \left(\sum_{j,k,\tilde{\alpha}} \frac{\partial \mathcal{L}_A}{\partial z_{k;\tilde{\alpha}}^{(L)}} \frac{dz_{k;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(\ell)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_\nu^{(\ell_a)}} \right) = -\eta \sum_{\nu,j,\tilde{\alpha}} \lambda_{\mu\nu}^{(\ell_a)} \epsilon_{j;\tilde{\alpha}}^{(\ell)} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_\nu^{(\ell_a)}}, \quad (11.4)$$

最后一个等号引入了第 ℓ 层误差因子：

$$\epsilon_{j;\tilde{\alpha}}^{(\ell)} \equiv \sum_{k=1}^{n_L} \frac{\partial \mathcal{L}_A}{\partial z_{k;\tilde{\alpha}}^{(L)}} \frac{dz_{k;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(\ell)}} = \frac{d\mathcal{L}_A}{dz_{j;\tilde{\alpha}}^{(\ell)}}. \quad (11.5)$$

把这种形式的参数更新 (11.4) 代入第 ℓ 层预激活量更新 (11.2)，二阶展开成为

$$\begin{aligned} dz_{i;\delta}^{(\ell)} = & -\eta \sum_{j,\tilde{\alpha}} \left(\sum_{\ell_1=1}^{\ell} \sum_{\mu,\nu} \lambda_{\mu\nu}^{(\ell_1)} \frac{dz_{i;\delta}^{(\ell)}}{d\theta_\mu^{(\ell_1)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_\nu^{(\ell_1)}} \right) \epsilon_{j;\tilde{\alpha}}^{(\ell)} \\ & + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \left(\sum_{\ell_1,\ell_2=1}^{\ell} \sum_{\substack{\mu_1,\nu_1, \\ \mu_2,\nu_2}} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \frac{d^2 z_{i;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{j_1;\tilde{\alpha}_1}^{(\ell)}}{d\theta_{\nu_1}^{(\ell_1)}} \frac{dz_{j_2;\tilde{\alpha}_2}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}} \right) \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} \\ & + \dots, \end{aligned} \quad (11.6)$$

它关于这些误差因子是二次的。这里，以逐层方式处理参数、并把每个学习率张量 $\lambda_{\mu\nu}^{(\ell_a)}$ 限制在单层 ℓ_a 内至关重要；否则，分解 (11.4) 和更新方程 (11.6) 都会复杂得多。

自然地，更新方程 (11.6) 第一个圆括号中的对象，就是随机的第 ℓ 层 NTK (8.5)：

$$\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} \equiv \sum_{\ell_1=1}^{\ell} \sum_{\mu,\nu} \lambda_{\mu\nu}^{(\ell_1)} \frac{dz_{i_1;\delta_1}^{(\ell)}}{d\theta_\mu^{(\ell_1)}} \frac{dz_{i_2;\delta_2}^{(\ell)}}{d\theta_\nu^{(\ell_1)}}, \quad (11.7)$$

你现在对此已经非常熟悉；不过在这个版本的定义中，我们显式写出对层的求和，而参数指标 μ, ν 的求和则逐层进行。

相比之下，第二个圆括号中的对象是新的。²¹¹ 把这个对象称为随机的第 ℓ 层神经正切核微分 (dNTK)，并记作

$$d\widehat{H}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \equiv \sum_{\ell_1,\ell_2=1}^{\ell} \sum_{\substack{\mu_1,\nu_1, \\ \mu_2,\nu_2}} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \frac{d^2 z_{i_0;\delta_0}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{i_1;\delta_1}^{(\ell)}}{d\theta_{\nu_1}^{(\ell_1)}} \frac{dz_{i_2;\delta_2}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}}. \quad (11.8)$$

²¹¹ 这个对象大约同时首次出现在文献 [66] 和 [67] 中，当时尚未命名。这里将计算它的递推，确定它随深度的标度，并通过强调它与表征学习的联系来阐明其物理重要性。

NTK 与 dNTK 上的帽子提醒我们，这些对象是随机的，依赖初始化时模型参数的具体实现。还可从定义看出，dNTK 关于第二、第三对指标 $(i_1, \delta_1) \leftrightarrow (i_2, \delta_2)$ 对称，而第一对神经元-样本指标 (i_0, δ_0) 则与另两对不同。

利用定义 (11.7) 和 (11.8)，二阶展开 (11.6) 可更紧凑地写成

$$\vec{dz}_{i;\delta}^{(\ell)} = -\eta \sum_{j,\tilde{\alpha}} \widehat{H}_{ij;\delta\tilde{\alpha}}^{(\ell)} \epsilon_{j;\tilde{\alpha}}^{(\ell)} + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)} \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} + \dots \quad (11.9)$$

换言之，这是误差因子的幂级数。为了最终理解预激活量在梯度下降下以 $1/n$ 领先阶如何演化，实际上需要把展开推进到 η^3 阶，这又要求引入几个额外张量。暂且不为此操心，将它留到 §∞。无论还有哪些高阶项，从 (11.9) 已经可以看出，需要掌握预激活量——它编码误差因子 $\epsilon_{j;\tilde{\alpha}}^{(\ell)}$ ——、NTK $\widehat{H}_{ij;\delta\tilde{\alpha}}^{(\ell)}$ 与 dNTK $\widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)}$ 的联合统计量。

最后，为解释 dNTK 名称与符号的选择，考虑梯度下降一步后第 ℓ 层 NTK 的领先阶更新：

$$\begin{aligned} dH_{i_1i_2;\delta_1\delta_2}^{(\ell)} &\equiv H_{i_1i_2;\delta_1\delta_2}^{(\ell)}(t=1) - H_{i_1i_2;\delta_1\delta_2}^{(\ell)}(t=0) \\ &= \sum_{\ell_1=1}^{\ell} \sum_{\mu_1} \frac{dH_{i_1i_2;\delta_1\delta_2}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)}} d\theta_{\mu_1}^{(\ell_1)} + \dots \\ &= -\eta \sum_{\ell_1=1}^{\ell} \sum_{\mu_1} \left[\frac{d}{d\theta_{\mu_1}^{(\ell_1)}} \left(\sum_{\ell_2=1}^{\ell} \sum_{\mu_2,\nu_2} \lambda_{\mu_2\nu_2}^{(\ell_2)} \frac{dz_{i_1;\delta_1}^{(\ell_2)}}{d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{i_2;\delta_2}^{(\ell_2)}}{d\theta_{\nu_2}^{(\ell_2)}} \right) \right] \left[\sum_{\nu_1} \lambda_{\mu_1\nu_1}^{(\ell_1)} \sum_{j,\tilde{\alpha}} \frac{dz_{j;\tilde{\alpha}}^{(\ell_1)}}{d\theta_{\nu_1}^{(\ell_1)}} \epsilon_{j;\tilde{\alpha}}^{(\ell)} \right] + \dots \\ &= -\eta \sum_{j,\tilde{\alpha}} \left[\sum_{\ell_1,\ell_2=1}^{\ell} \sum_{\mu_1,\nu_1,\mu_2,\nu_2} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \frac{d^2z_{i_1;\delta_1}^{(\ell_2)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{i_2;\delta_2}^{(\ell_2)}}{d\theta_{\nu_2}^{(\ell_2)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell_1)}}{d\theta_{\nu_1}^{(\ell_1)}} \right] \epsilon_{j;\tilde{\alpha}}^{(\ell)} \\ &\quad - \eta \sum_{j,\tilde{\alpha}} \left[\sum_{\ell_1,\ell_2=1}^{\ell} \sum_{\mu_1,\nu_1,\mu_2,\nu_2} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \frac{dz_{i_1;\delta_1}^{(\ell_2)}}{d\theta_{\mu_2}^{(\ell_2)}} \frac{d^2z_{i_2;\delta_2}^{(\ell_2)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\nu_2}^{(\ell_2)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell_1)}}{d\theta_{\nu_1}^{(\ell_1)}} \right] \epsilon_{j;\tilde{\alpha}}^{(\ell)} + \dots \\ &= -\eta \sum_{j,\tilde{\alpha}} \left(\widehat{dH}_{i_1i_2j;\delta_1\delta_2\tilde{\alpha}}^{(\ell)} + \widehat{dH}_{i_2i_1j;\delta_2\delta_1\tilde{\alpha}}^{(\ell)} \right) \epsilon_{j;\tilde{\alpha}}^{(\ell)} + \dots \end{aligned} \quad (11.10)$$

第三行代入了 NTK 的定义 (11.7)，并对 $\ell_1 \leq \ell$ 使用参数更新 (11.4)；最后一行使用 dNTK 的定义 (11.8)。因而可见，dNTK 乘以全局学习率并与第 ℓ 层误差因子缩并后，给出梯度下降一步之后第 ℓ 层 NTK 的更新。²¹²

由于无限宽度 NTK 是冻结的， $\widehat{H}^{(\ell)} \rightarrow \Theta^{(\ell)}$ ，NTK 更新与 dNTK 的关系意味着 dNTK 必定是有限宽度效应，并在严格无限宽度极限下消失， $\widehat{dH}^{(\ell)} \rightarrow 0$ 。类似地，在无限宽度下，我们把预激活量更新 (11.9) 截断为关于全局学习率 η 的线性项，参见 (10.2)。下一节将递归计算 dNTK，显式说明 $\widehat{dH}^{(\ell)} = O(1/n)$ ，从而验证以上所有结论。

²¹²请不要把表示 NTK 第一次更新的斜体、带横线且不带帽记号 $dH_{i_1i_2;\delta_1\delta_2}^{(\ell)}$ ，与表示 dNTK 的正体、不带横线且带帽记号 $\widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2}^{(\ell)}$ 混淆。本章将关注 dNTK 的统计量；下一章计算 NTK 动力学时不会使用前一种记号。

11.2 dNTK 的 RG 流

顾名思义, 本节的结构与 §4 和 §8 平行; 前者推导预激活量分布 $p(z^{(\ell)}|\mathcal{D})$ 的逐层表征群 (RG) 流, 后者推导 NTK-预激活量联合分布 $p(z^{(\ell)}, \hat{H}^{(\ell)}|\mathcal{D})$ 的逐层 RG 流. 具体而言, 现在要推导预激活量、NTK 与 dNTK 的有效第 ℓ 层联合分布:

$$p(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}|\mathcal{D}). \quad (11.11)$$

这一分析之所以重要, 有两个原因: (i) 第一, 理解该第 ℓ 层联合分布在 $1/n$ 阶的统计量, 是理解以基于梯度的学习训练深度神经网络时领先非平凡有限宽度修正的必要前提; (ii) 第二, 我们将在 §11.4 中看到, 非零 dNTK 足以使网络展现表征学习, 因此, 只要说明 dNTK 为 $1/n$ 阶, 就能确立领先阶有限宽度有效理论能够描述深度学习的这一基本性质.

第零步, 建立 dNTK 的随机迭代方程 (§11.2.0). 随后开始统计分析: 第一步, 说明 dNTK 在第一层恒等于零 (§11.2.1); 第二步, 说明 dNTK 与第二层预激活量之间存在非平凡的交叉相关 (§11.2.2); 第三步也是最后一步, 推导一个一般递推, 控制这种 dNTK-预激活量交叉相关在更深层中的累积 (§11.2.3).

11.2.0 dNTK 的前向方程

在推导 NTK 统计量的递推之前, 我们曾在 §8.0 中先推导 NTK 的随机前向迭代方程 (8.12); 这里也要为 dNTK 推导这样的方程.

先写出第 $(\ell+1)$ 层的 dNTK 定义 (11.8):

$$\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell+1)} \equiv \sum_{\ell_1, \ell_2=1}^{\ell+1} \left[\sum_{\substack{\mu_1, \nu_1, \\ \mu_2, \nu_2}} \lambda_{\mu_1 \nu_1}^{(\ell_1)} \lambda_{\mu_2 \nu_2}^{(\ell_2)} \frac{d^2 z_{i_0; \delta_0}^{(\ell+1)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{i_1; \delta_1}^{(\ell+1)}}{d\theta_{\nu_1}^{(\ell_1)}} \frac{dz_{i_2; \delta_2}^{(\ell+1)}}{d\theta_{\nu_2}^{(\ell_2)}} \right]. \quad (11.12)$$

为了确定其前向方程, 需要显式计算关于第 $(\ell+1)$ 层参数的导数, 还要用链式法则把所有第 $(\ell+1)$ 层量改写成第 ℓ 层量. 因而, 根据 ℓ_1 和 ℓ_2 的取值, 对层的二重求和有三种情形需要考虑.

第一, 当两层都取最大值 $\ell_1 = \ell_2 = \ell+1$ 时, 没有贡献. 最后一次回顾预激活量的前向方程:

$$z_{i; \delta}^{(\ell+1)} = b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma_{j; \delta}^{(\ell)}, \quad (11.13)$$

可以看到, 第 $(\ell+1)$ 层预激活量总是关于第 $(\ell+1)$ 层模型参数 $\theta_\mu^{(\ell+1)}$ 线性的. 所以在这种情形下, dNTK 定义 (11.12) 中的二阶导数消失.

第二, 当 $\ell_1 = \ell+1$ 且 $\ell_2 < \ell+1$ 时, 第 $(\ell+1)$ 层权重有贡献, 但该层偏置没有贡献. 先考虑偏置 $\theta_{\mu_1}^{(\ell_1)} = b_j^{(\ell+1)}$, 关于第 $(\ell+1)$ 层的导数给出 Kronecker delta:

$$\frac{dz_{i; \delta}^{(\ell+1)}}{db_j^{(\ell+1)}} = \delta_{ij}, \quad (11.14)$$

所以二阶导数再次消失：

$$\frac{d^2 z_{i;\delta}^{(\ell+1)}}{db_j^{(\ell+1)} d\theta_{\mu_2}^{(\ell_2)}} = 0. \quad (11.15)$$

再考虑权重矩阵 $\theta_{\mu_1}^{(\ell_1)} = W_{jk}^{(\ell+1)}$ ，关于第 $(\ell+1)$ 层的导数不再是常数：

$$\frac{dz_{i;\delta}^{(\ell+1)}}{dW_{jk}^{(\ell+1)}} = \delta_{ij} \sigma_{k;\delta}^{(\ell)}. \quad (11.16)$$

因此，二阶导数得到非平凡结果：

$$\frac{d^2 z_{i;\delta}^{(\ell+1)}}{dW_{jk}^{(\ell+1)} d\theta_{\mu_2}^{(\ell_2)}} = \delta_{ij} \sigma_{k;\delta}'^{(\ell)} \frac{dz_{k;\delta}^{(\ell)}}{d\theta_{\mu_2}^{(\ell_2)}}, \quad (11.17)$$

而余下的一阶导数由链式法则给出：

$$\frac{dz_{i;\delta}^{(\ell+1)}}{d\theta_{\nu_2}^{(\ell_2)}} = \sum_k W_{ik}^{(\ell+1)} \sigma_{k;\delta}'^{(\ell)} \frac{dz_{k;\delta}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}}, \quad (11.18)$$

把这三个导数结果 (11.16)、(11.17) 和 (11.18) 代入 dNTK 定义 (11.12)，计算 $\ell_1 = \ell+1$ 且 $\ell_2 < \ell+1$ 的各项，得到

$$\begin{aligned} & \sum_{\ell_2=1}^{\ell} \sum_{j,k} \lambda_{W_{jk}^{(\ell+1)} W_{jk}^{(\ell+1)}} \sum_{\mu_2, \nu_2} \lambda_{\mu_2 \nu_2}^{(\ell_2)} \frac{d^2 z_{i_0; \delta_0}^{(\ell+1)}}{dW_{jk}^{(\ell+1)} d\theta_{\mu_2}^{(\ell_2)}} \frac{dz_{i_1; \delta_1}^{(\ell+1)}}{dW_{jk}^{(\ell+1)}} \frac{dz_{i_2; \delta_2}^{(\ell+1)}}{d\theta_{\nu_2}^{(\ell_2)}} \\ &= \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{\ell_2=1}^{\ell} \sum_{j,k} \sum_{\mu_2, \nu_2} \lambda_{\mu_2 \nu_2}^{(\ell_2)} \left(\delta_{i_0 j} \sigma_{k; \delta_0}'^{(\ell)} \frac{dz_{k; \delta_0}^{(\ell)}}{d\theta_{\mu_2}^{(\ell_2)}} \right) \left(\delta_{i_1 j} \sigma_{k; \delta_1}^{(\ell)} \right) \left(\sum_{k_2} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_2; \delta_2}'^{(\ell)} \frac{dz_{k_2; \delta_2}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}} \right) \\ &= \frac{\lambda_W^{(\ell+1)}}{n_\ell} \delta_{i_0 i_1} \sum_{k_0, k_2} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}'^{(\ell)} \sigma_{k_0; \delta_1}^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \hat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)}. \end{aligned} \quad (11.19)$$

为得到这一结果，第二行采用了权重的单一层内学习率选择 (8.6)：

$$\lambda_{W_{j_1 k_1}^{(\ell+1)} W_{j_2 k_2}^{(\ell+1)}} = \delta_{j_1 j_2} \delta_{k_1 k_2} \frac{\lambda_W^{(\ell+1)}}{n_\ell}, \quad (11.20)$$

其中尤为重要是用 n_ℓ 作了重标度；第三行则使用随机 NTK 的定义 (11.7) 并重新标记了一个哑指标. 由对称性可知，当 $\ell_2 = \ell+1$ 且 $\ell_1 < \ell+1$ 时必有类似贡献. 交换神经元-样本指标对 $(i_1, \delta_1) \leftrightarrow (i_2, \delta_2)$ ，即可由 (11.19) 得到该项.

第三也是最后一种情形，当 $\ell_1 < \ell+1$ 且 $\ell_2 < \ell+1$ 时，偏置和权重都对二阶导数有贡献. 当 $\theta_{\mu}^{(\ell_1)}$ 与 $\theta_{\nu}^{(\ell_2)}$ 都不来自第 $(\ell+1)$ 层时，它们的一阶导数已在 (11.18) 中算出，而二阶导数为

$$\frac{d^2 z_{i;\delta}^{(\ell+1)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} = \sum_k W_{ik}^{(\ell+1)} \sigma_{k;\delta}''^{(\ell)} \frac{dz_{k;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)}} \frac{dz_{k;\delta}^{(\ell)}}{d\theta_{\mu_2}^{(\ell_2)}} + \sum_k W_{ik}^{(\ell+1)} \sigma_{k;\delta}'^{(\ell)} \frac{d^2 z_{k;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}}. \quad (11.21)$$

把这些二阶导数项乘以学习率张量 $\lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)}$ 及相应的一阶导数 (11.18), 再执行 dNTK 定义 (11.12) 中对 $\ell_1, \ell_2, \mu_1, \nu_1, \mu_2, \nu_2$ 的全部求和, 则 (11.21) 的第一项贡献为

$$\sum_{k_0, k_1, k_2} W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}''^{(\ell)} \sigma_{k_1; \delta_1}'^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)}, \quad (11.22)$$

这里两次使用 NTK 的定义 (11.7); 而 (11.21) 的第二项贡献为

$$\sum_{k_0, k_1, k_2} W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}'^{(\ell)} \sigma_{k_1; \delta_1}'^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \widehat{dH}_{k_0 k_1 k_2; \delta_0 \delta_1 \delta_2}^{(\ell)}, \quad (11.23)$$

这里使用了一次 dNTK 的定义 (11.8).

合并三类贡献 (11.19)、(11.22) 和 (11.23), 得到一个相当复杂的随机迭代方程:

$$\begin{aligned} \widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell+1)} &= \sum_{k_0, k_1, k_2} W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}'^{(\ell)} \sigma_{k_1; \delta_1}'^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \widehat{dH}_{k_0 k_1 k_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \\ &+ \sum_{k_0, k_1, k_2} W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}''^{(\ell)} \sigma_{k_1; \delta_1}'^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \\ &+ \frac{\lambda_W^{(\ell+1)}}{n_\ell} \delta_{i_0 i_1} \sum_{k_0, k_2} W_{i_2 k_2}^{(\ell+1)} \sigma_{k_0; \delta_0}'^{(\ell)} \sigma_{k_0; \delta_1}^{(\ell)} \sigma_{k_2; \delta_2}'^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \\ &+ \frac{\lambda_W^{(\ell+1)}}{n_\ell} \delta_{i_0 i_2} \sum_{k_0, k_1} W_{i_1 k_1}^{(\ell+1)} \sigma_{k_0; \delta_0}'^{(\ell)} \sigma_{k_1; \delta_1}'^{(\ell)} \sigma_{k_0; \delta_2}^{(\ell)} \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)}. \end{aligned} \quad (11.24)$$

这就是 dNTK 的前向方程; 接下来将推导确定其统计量的递推.

11.2.1 第一层：零 dNTK

回顾 §4.1 和 §8.1，在初始化时，第一层预激活量

$$z_{i;\delta}^{(1)} \equiv b_i^{(1)} + \sum_{k=1}^{n_0} W_{ik}^{(1)} x_{k;\delta}, \quad (11.25)$$

服从零均值高斯分布 (4.23)，而 NTK $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(1)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(1)}$ 是确定性的 (8.23)。

正如刚才所讨论，由于预激活量关于模型参数是线性的，其二阶导数必定消失。因此，dNTK 在第一层恒等于零：

$$\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(1)} \equiv \sum_{\substack{\mu_1, \nu_1, \\ \mu_2, \nu_2}} \lambda_{\mu_1 \nu_1}^{(1)} \lambda_{\mu_2 \nu_2}^{(1)} \frac{d^2 z_{i_0; \delta_0}^{(1)}}{d\theta_{\mu_1}^{(1)} d\theta_{\mu_2}^{(1)}} \frac{dz_{i_1; \delta_1}^{(1)}}{d\theta_{\nu_1}^{(1)}} \frac{dz_{i_2; \delta_2}^{(1)}}{d\theta_{\nu_2}^{(1)}} = 0. \quad (11.26)$$

这给出了递推的初始条件。

这一结果本就在预期之中，因为第一层 NTK (8.23) 与模型参数无关，因而不可能随任何训练而改变。正如前面所见，第一层预激活量是零均值高斯变量，而第一层 NTK 是固定的；与此类似，dNTK 的这一第一层结果将代表它在所有层中的无限宽度极限。

11.2.2 第二层：非零 dNTK

现在分析第二层的 dNTK (11.24)。再次回顾，第一层 NTK (8.23) 是确定性的，并且关于神经元指标是对角的，即 $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(1)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(1)}$ ；同时第一次回顾，由 (11.26) 可知 dNTK 在第一层消失， $\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(1)} = 0$ 。因此前向方程 (11.24) 在第二层简化为

$$\begin{aligned} \widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(2)} &= H_{\delta_0 \delta_1}^{(1)} H_{\delta_0 \delta_2}^{(1)} \sum_{k=1}^{n_1} W_{i_0 k}^{(2)} W_{i_1 k}^{(2)} W_{i_2 k}^{(2)} \sigma_{k; \delta_0}''^{(1)} \sigma_{k; \delta_1}'^{(1)} \sigma_{k; \delta_2}'^{(1)} \\ &\quad + \delta_{i_0 i_1} \frac{\lambda_W^{(2)}}{n_1} H_{\delta_0 \delta_2}^{(1)} \sum_{k=1}^{n_1} W_{i_2 k}^{(2)} \sigma_{k; \delta_0}'^{(1)} \sigma_{k; \delta_1}^{(1)} \sigma_{k; \delta_2}'^{(1)} \\ &\quad + \delta_{i_0 i_2} \frac{\lambda_W^{(2)}}{n_1} H_{\delta_0 \delta_1}^{(1)} \sum_{k=1}^{n_1} W_{i_1 k}^{(2)} \sigma_{k; \delta_0}'^{(1)} \sigma_{k; \delta_1}'^{(1)} \sigma_{k; \delta_2}^{(1)}. \end{aligned} \quad (11.27)$$

有趣的是，由于每一项都含有奇数个权重，dNTK 的均值将消失；要找到领先的非零 dNTK 统计量，就必须考察交叉相关。

最简单的是它与单个预激活量的交叉相关。考虑第二层 dNTK (11.27) 与第二层预激活量

$$z_{i;\delta}^{(2)} = b_i^{(2)} + \sum_{k=1}^{n_1} W_{ik}^{(2)} \sigma_{k;\delta}^{(1)}, \quad (11.28)$$

的乘积并取期望, 得到

$$\begin{aligned}
& \mathbb{E} \left[\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(2)} z_{i_3; \delta_3}^{(2)} \right] \\
&= H_{\delta_0 \delta_1}^{(1)} H_{\delta_0 \delta_2}^{(1)} \left(\frac{C_W^{(2)}}{n_1} \right)^2 (\delta_{i_0 i_3} \delta_{i_1 i_2} + \delta_{i_0 i_1} \delta_{i_2 i_3} + \delta_{i_0 i_2} \delta_{i_1 i_3}) \sum_{k=1}^{n_1} \mathbb{E} \left[\sigma_{k; \delta_0}''^{(1)} \sigma_{k; \delta_1}'^{(1)} \sigma_{k; \delta_2}'^{(1)} \sigma_{k; \delta_3}^{(1)} \right] \\
&\quad + \frac{\lambda_W^{(2)}}{n_1} H_{\delta_0 \delta_2}^{(1)} \delta_{i_0 i_1} \delta_{i_2 i_3} \frac{C_W^{(2)}}{n_1} \sum_{k=1}^{n_1} \mathbb{E} \left[\sigma_{k; \delta_0}'^{(1)} \sigma_{k; \delta_1}^{(1)} \sigma_{k; \delta_2}'^{(1)} \sigma_{k; \delta_3}^{(1)} \right] \\
&\quad + \frac{\lambda_W^{(2)}}{n_1} H_{\delta_0 \delta_1}^{(1)} \delta_{i_0 i_2} \delta_{i_1 i_3} \frac{C_W^{(2)}}{n_1} \sum_{k=1}^{n_1} \mathbb{E} \left[\sigma_{k; \delta_0}'^{(1)} \sigma_{k; \delta_1}^{(1)} \sigma_{k; \delta_2}^{(1)} \sigma_{k; \delta_3}'^{(1)} \right] \\
&= \frac{1}{n_1} (\delta_{i_0 i_3} \delta_{i_1 i_2} + \delta_{i_0 i_1} \delta_{i_2 i_3} + \delta_{i_0 i_2} \delta_{i_1 i_3}) C_W^{(2)} H_{\delta_0 \delta_1}^{(1)} C_W^{(2)} H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3} \rangle_{G^{(1)}} \\
&\quad + \frac{1}{n_1} \delta_{i_0 i_1} \delta_{i_2 i_3} \lambda_W^{(2)} C_W^{(2)} H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_0}' \sigma_{\delta_1} \sigma_{\delta_2}' \sigma_{\delta_3} \rangle_{G^{(1)}} \\
&\quad + \frac{1}{n_1} \delta_{i_0 i_2} \delta_{i_1 i_3} \lambda_W^{(2)} C_W^{(2)} H_{\delta_0 \delta_1}^{(1)} \langle \sigma_{\delta_0}' \sigma_{\delta_1}' \sigma_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(1)}} \tag{11.29}
\end{aligned}$$

为得到最后的结果, 第一个等式中删去了 (11.28) 的偏置项, 因为它在期望下消失; 还利用 $\mathbb{E} \left[W_{i_1 j_1}^{(2)} W_{i_2 j_2}^{(2)} \right] = \delta_{i_1 i_2} \delta_{j_1 j_2} C_W^{(2)} / n_1$ (2.20) 对权重执行了各种 Wick 缩并. 在第二个等式中, 回顾第一层预激活量分布是零均值高斯分布, 其二点相关函数关于神经元指标对角, 即 $\mathbb{E} \left[z_{i_1; \delta_1}^{(1)} z_{i_2; \delta_2}^{(1)} \right] = \delta_{i_1 i_2} G_{\delta_1 \delta_2}^{(1)}$ (4.23); 据此以高斯期望替代完整期望, 然后完成求和.

正如之前对 NTK 方差 (8.31) 和 NTK-预激活量交叉相关 (8.37) 所做的那样, 把这一 dNTK-预激活量交叉相关 (11.29) 分解为两个只含样本指标的张量会很方便:

$$\mathbb{E} \left[\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(2)} z_{i_3; \delta_3}^{(2)} \right] \equiv \frac{1}{n_1} \left[\delta_{i_0 i_3} \delta_{i_1 i_2} P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)} + \delta_{i_0 i_1} \delta_{i_2 i_3} Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)} + \delta_{i_0 i_2} \delta_{i_1 i_3} Q_{\delta_0 \delta_2 \delta_1 \delta_3}^{(2)} \right]. \tag{11.30}$$

与第二层交叉相关的显式公式 (11.29) 比较可知, 这些张量定义为

$$P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)} \equiv \left(C_W^{(2)} \right)^2 H_{\delta_0 \delta_1}^{(1)} H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3} \rangle_{G^{(1)}}, \tag{11.31}$$

$$Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)} \equiv \left(C_W^{(2)} \right)^2 H_{\delta_0 \delta_1}^{(1)} H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3} \rangle_{G^{(1)}} + \lambda_W^{(2)} C_W^{(2)} H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_0}' \sigma_{\delta_1} \sigma_{\delta_2}' \sigma_{\delta_3} \rangle_{G^{(1)}}, \tag{11.32}$$

并且它们显然都是一阶的.²¹³ 总体而言, dNTK-预激活量交叉相关 (11.30) 为 $1/n_1$ 阶, 并在严格无限宽度极限 $n_1 \rightarrow \infty$ 下消失.

张量 (11.31) 和 (11.32) 及其更深层对应物控制预激活量与 dNTK 之间所有领先有限宽度相关性; 事实上, 它们概括了 dNTK 在 $1/n$ 阶的全部效应. 如接下来将说明的, 在

²¹³交叉相关张量 $P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)}$ (11.31)——以及更一般地, 更深层中的 $P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)}$ ——只在交换中间两个样本指标 $\delta_1 \leftrightarrow \delta_2$ 下对称. 与此同时, 从 (11.32) 可以明显看出, 另一个交叉相关张量 $Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)}$ 不具有任何对称性.

这一阶, 任何其他 dNTK-预激活量交叉相关函数, 例如 $\mathbb{E} \left[\widehat{\mathrm{d}H}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} z_{j_3; \delta_3}^{(\ell)} z_{j_4; \delta_4}^{(\ell)} z_{j_5; \delta_5}^{(\ell)} \right]$, 总能表示成 $P^{(\ell)}$ 与 $Q^{(\ell)}$ 的某种组合.

11.2.3 更深层: 增长的 dNTK

与之前的 §4.1 || §8.1 || §11.2.1 和 §4.2 || §8.2 || §11.2.2 一样, 本小节也与分析更深层 RG 流的其他小节平行 (§4.3 || §8.3) .

为继续推进, 首先需要计算一个插入三个权重的层间公式 (扩展 §8.3.0 中的工作), 随后立即用它得到 dNTK-预激活量交叉相关的递推.

层间插曲 2: 再论层间相关

由于 dNTK 的前向方程 (11.24) 含有一个或三个第 $(\ell + 1)$ 层权重矩阵的项, 因此需要插入一个或三个权重的层间公式.

先回顾层间相关的生成函数 (8.53):

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) e^{\sum_{i,j} \mathcal{J}_{ij} W_{ij}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}, \widehat{\mathrm{d}H}^{(\ell)}) \right] \\ &= \exp \left(\frac{C_W^{(\ell+1)}}{2n_\ell} \sum_{i,j} \mathcal{J}_{ij}^2 \right) \mathbb{E} \left[\left\langle \left\langle \mathcal{O}(z_{i;\delta}^{(\ell+1)}) + \frac{C_W^{(\ell+1)}}{n_\ell} \sum_{j=1}^{n_\ell} \mathcal{J}_{ij} \sigma_{j;\delta}^{(\ell)} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}, \widehat{\mathrm{d}H}^{(\ell)}) \right]. \end{aligned} \quad (11.33)$$

在这一公式中, $\mathcal{O}$ 是只依赖第 $(\ell + 1)$ 层预激活量的一般函数, 而 $\mathcal{Q}$ 是任意第 ℓ 层对象的函数; 特别地, 由于该公式的原始推导并不依赖 $\mathcal{Q}$ 的具体性质, 这里也把第 ℓ 层 dNTK 纳入其宗量.

基于这一点, 在分析无限宽度极限中 (缺乏) 表征学习时, 我们曾把插入一个权重的层间公式写成 (10.10). 为免你翻回去回忆, 现作少量记号调整后重录如下:

$$\begin{aligned} & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{ij}^{(\ell+1)} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}, \widehat{\mathrm{d}H}^{(\ell)}) \right] \\ &= \frac{C_W^{(\ell+1)}}{n_\ell} \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i;\delta}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{j;\delta}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \widehat{H}^{(\ell)}, \widehat{\mathrm{d}H}^{(\ell)}) \right]. \end{aligned} \quad (11.34)$$

只需对生成函数 (11.33) 的源作一次 $\frac{d}{d\mathcal{J}_{ij}}$ 微分, 再把源设为零, 即可直接重新推导此式.

相比之下, 插入三个权重的公式是新的. 对生成函数 (11.33) 分别关于源 $\mathcal{J}_{i_0 j_0}$ 、 $\mathcal{J}_{i_1 j_1}$

和 $\mathcal{J}_{i_2 j_2}$ 各作一次微分, 再把源设为零 $\mathcal{J} = 0$, 得到

$$\begin{aligned}
 & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_0 j_0}^{(\ell+1)} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}) \right] \\
 &= \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \delta_{i_0 i_1} \delta_{j_0 j_1} \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{j_2; \delta}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}) \right] \\
 &+ \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \delta_{i_0 i_2} \delta_{j_0 j_2} \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_1; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{j_1; \delta}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}) \right] \\
 &+ \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^2 \delta_{i_1 i_2} \delta_{j_1 j_2} \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_0; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{j_0; \delta}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}) \right] \\
 &+ \left(\frac{C_W^{(\ell+1)}}{n_\ell} \right)^3 \sum_{\delta_0, \delta_1, \delta_2 \in \mathcal{D}} \mathbb{E} \left[\left\langle \left\langle \frac{\partial^3 \mathcal{O}}{\partial z_{i_0; \delta_0}^{(\ell+1)} \partial z_{i_1; \delta_1}^{(\ell+1)} \partial z_{i_2; \delta_2}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{j_0; \delta_0}^{(\ell)} \sigma_{j_1; \delta_1}^{(\ell)} \sigma_{j_2; \delta_2}^{(\ell)} \mathcal{Q}(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)}) \right].
 \end{aligned} \tag{11.35}$$

直观上可作如下理解: 前三项各自来自先在两个插入权重之间形成一次 Wick 缩并, 再让余下的权重与 $\mathcal{O}$ 中 $z^{(\ell+1)}$ 所隐藏的一个权重形成另一次缩并; 最后一项则来自三个插入权重分别与可观测量 $\mathcal{O}$ 内的其他权重形成缩并。

dNTK-预激活量交叉相关

首先利用上面推导的层间公式来说明: 在 $1/n$ 阶, dNTK 对联合分布 $p(z^{(\ell)}, \hat{H}^{(\ell)}, \widehat{dH}^{(\ell)} | \mathcal{D})$ 统计量的全部贡献, 都由 dNTK 与单个预激活量的交叉相关捕获, 即

$\mathbb{E} \left[\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} z_{i_3; \delta_3}^{(\ell+1)} \right]$. 为此, 考察如下极一般的 dNTK-预激活量交叉相关函数:

$$\begin{aligned}
 & \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell+1)} \right] \\
 &= \delta_{i_0 i_1} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{k_0, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_2 k_2}^{(\ell+1)} \sigma'_{k_0; \delta_0}^{(\ell)} \sigma'_{k_0; \delta_1}^{(\ell)} \sigma'_{k_2; \delta_2}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] \\
 &+ \delta_{i_0 i_2} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{k_0, k_1} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_1 k_1}^{(\ell+1)} \sigma'_{k_0; \delta_0}^{(\ell)} \sigma'_{k_1; \delta_1}^{(\ell)} \sigma'_{k_0; \delta_2}^{(\ell)} \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \right] \\
 &+ \sum_{k_0, k_1, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma''_{k_0; \delta_0}^{(\ell)} \sigma'_{k_1; \delta_1}^{(\ell)} \sigma'_{k_2; \delta_2}^{(\ell)} \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] \\
 &+ \sum_{k_0, k_1, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma'_{k_0; \delta_0}^{(\ell)} \sigma'_{k_1; \delta_1}^{(\ell)} \sigma'_{k_2; \delta_2}^{(\ell)} \widehat{dH}_{k_0 k_1 k_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \right].
 \end{aligned} \tag{11.36}$$

这里, 我们把第 $(\ell + 1)$ 层预激活量的一般可观测量 $\mathcal{O}(z^{(\ell+1)})$ 乘到 dNTK 前向方程 (11.24) 上并取期望. 四项的排列顺序也与下面依次计算它们的顺序一致。

先化简前两项. 对 (11.36) 的第一项应用单权重插入的层间公式 (11.34), 得到

$$\begin{aligned}
& \frac{\lambda_W^{(\ell+1)}}{n_\ell} \delta_{i_0 i_1} \sum_{k_0, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_2 k_2}^{(\ell+1)} \sigma'_{k_0; \delta_0}(\ell) \sigma'_{k_0; \delta_1}(\ell) \sigma'_{k_2; \delta_2}(\ell) \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] \\
&= \frac{\lambda_W^{(\ell+1)} C_W^{(\ell+1)}}{n_\ell^2} \sum_{k_0, k_2} \sum_{\delta \in \mathcal{D}} \delta_{i_0 i_1} \mathbb{E} \left[\left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{\widehat{G}^{(\ell+1)}} \sigma_{k_2; \delta}^{(\ell)} \sigma'_{k_0; \delta_0}(\ell) \sigma'_{k_0; \delta_1}(\ell) \sigma'_{k_2; \delta_2}(\ell) \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] \\
&= \frac{\lambda_W^{(\ell+1)} C_W^{(\ell+1)}}{n_\ell^2} \sum_{k, m} \sum_{\delta \in \mathcal{D}} \delta_{i_0 i_1} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \mathbb{E} \left[\sigma_{k; \delta_1}^{(\ell)} \sigma_{m; \delta}^{(\ell)} \sigma'_{k; \delta_0}(\ell) \sigma'_{m; \delta_2}(\ell) \widehat{H}_{km; \delta_0 \delta_2}^{(\ell)} \right] + O\left(\frac{1}{n^2}\right) \\
&= \frac{1}{n_\ell} \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} \sum_{\delta \in \mathcal{D}} \delta_{i_0 i_1} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} F_{\delta_1 \delta_0 \delta_3 \delta_2}^{(\ell+1)} + O\left(\frac{1}{n^2}\right),
\end{aligned} \tag{11.37}$$

第三行用 Schwinger–Dyson 公式 (8.70) 围绕均值 $G^{(\ell+1)}$ 展开度量涨落, 并注意含涨落的第二项是次领先的; 最后一行则把余下期望辨认为 (8.69) 所定义的 NTK–预激活量交叉相关张量 $F^{(\ell+1)}$ (相差若干常数).²¹⁴

类似地, 对 (11.36) 的第二项, 除交换神经元–样本指标对 $(i_1, \delta_1) \leftrightarrow (i_2, \delta_2)$ 外, 得到完全相同的贡献.

接着处理 (11.36) 的第三项. 应用三权重插入的层间公式 (11.35), 得到

$$\begin{aligned}
& \sum_{k_0, k_1, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma''_{k_0; \delta_0}(\ell) \sigma'_{k_1; \delta_1}(\ell) \sigma'_{k_2; \delta_2}(\ell) \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] \\
&= \frac{(C_W^{(\ell+1)})^2}{n_\ell} \delta_{i_0 i_1} \sum_{\delta \in \mathcal{D}} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma_{m; \delta}^{(\ell)} \sigma''_{k; \delta_0}(\ell) \sigma'_{k; \delta_1}(\ell) \sigma'_{m; \delta_2}(\ell) \widehat{H}_{mk; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{km; \delta_0 \delta_2}^{(\ell)} \right] \right\} \\
&\quad + \frac{(C_W^{(\ell+1)})^2}{n_\ell} \delta_{i_0 i_2} \sum_{\delta \in \mathcal{D}} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_1; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma_{m; \delta}^{(\ell)} \sigma''_{k; \delta_0}(\ell) \sigma'_{k; \delta_2}(\ell) \sigma'_{m; \delta_1}(\ell) \widehat{H}_{mk; \delta_0 \delta_2}^{(\ell)} \widehat{H}_{km; \delta_0 \delta_1}^{(\ell)} \right] \right\} \\
&\quad + \frac{(C_W^{(\ell+1)})^2}{n_\ell} \delta_{i_1 i_2} \sum_{\delta \in \mathcal{D}} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_0; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma_{m; \delta}^{(\ell)} \sigma''_{m; \delta_0}(\ell) \sigma'_{k; \delta_1}(\ell) \sigma'_{k; \delta_2}(\ell) \widehat{H}_{mk; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{mk; \delta_0 \delta_2}^{(\ell)} \right] \right\} \\
&\quad + O\left(\frac{1}{n^2}\right),
\end{aligned} \tag{11.38}$$

其中每一项都再次用 Schwinger–Dyson 公式 (8.70) 围绕均值 $G^{(\ell+1)}$ 展开度量涨落, 保留均值度量给出的领先贡献, 再把高斯期望移到完整的第 ℓ 层期望之外. 注意, 最后一个本应正比于 $\partial^3 \mathcal{O}$ 的项是次领先的:

$$\begin{aligned}
& (C_W^{(\ell+1)})^3 \sum_{\delta, \delta_4, \delta_5 \in \mathcal{D}} \left\langle \left\langle \frac{\partial^3 \mathcal{O}}{\partial z_{i_0; \delta}^{(\ell+1)} \partial z_{i_1; \delta_4}^{(\ell+1)} \partial z_{i_2; \delta_5}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \\
& \quad \times \frac{1}{n_\ell^3} \sum_{k_0, k_1, k_2} \mathbb{E} \left[\sigma_{k_0; \delta}^{(\ell)} \sigma_{k_1; \delta_4}^{(\ell)} \sigma_{k_2; \delta_5}^{(\ell)} \sigma''_{k_0; \delta_0}(\ell) \sigma'_{k_1; \delta_1}(\ell) \sigma'_{k_2; \delta_2}(\ell) \widehat{H}_{k_0 k_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{k_0 k_2; \delta_0 \delta_2}^{(\ell)} \right] = O\left(\frac{1}{n^2}\right).
\end{aligned} \tag{11.39}$$

²¹⁴注意, 这是一个第 $(\ell+1)$ 层量, 而不是递推右端通常出现的第 ℓ 层量. 若愿意, 可用 F -递推 (8.79) 把它重新表示成一组更复杂的第 ℓ 层量.

要看出这一点, 把每个随机 NTK 按 (8.58) 分解为均值与涨落, $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(\ell)} + \widehat{\Delta H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)}$, 并计算所得四项. 每一种情况下, 由于 Kronecker delta 限制了三重求和, 和/或涨落带来额外的 $1/n$ 抑制, 所得项都是 $O(1/n^2)$.

最后处理一般交叉相关 (11.36) 的第四项. 再次应用三权重插入公式 (11.35) 并只取领先阶部分, 得到

$$\begin{aligned}
& \sum_{k_0, k_1, k_2} \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) W_{i_0 k_0}^{(\ell+1)} W_{i_1 k_1}^{(\ell+1)} W_{i_2 k_2}^{(\ell+1)} \sigma'_{k_0; \delta_0}(\ell) \sigma'_{k_1; \delta_1}(\ell) \sigma'_{k_2; \delta_2}(\ell) \widehat{\Delta H}_{k_0 k_1 k_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] \\
&= \frac{(C_W^{(\ell+1)})^2}{n_\ell} \sum_{\delta \in \mathcal{D}} \delta_{i_0 i_1} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma'_{k; \delta_0}(\ell) \sigma'_{k; \delta_1}(\ell) \sigma'_{m; \delta_2}(\ell) \sigma_{m; \delta}^{(\ell)} \widehat{\Delta H}_{k k m; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] \right\} \\
&+ \frac{(C_W^{(\ell+1)})^2}{n_\ell} \sum_{\delta \in \mathcal{D}} \delta_{i_0 i_2} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_1; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma'_{k; \delta_0}(\ell) \sigma'_{m; \delta_1}(\ell) \sigma'_{k; \delta_2}(\ell) \sigma_{m; \delta}^{(\ell)} \widehat{\Delta H}_{k m k; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] \right\} \\
&+ \frac{(C_W^{(\ell+1)})^2}{n_\ell} \sum_{\delta \in \mathcal{D}} \delta_{i_1 i_2} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_0; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} \left\{ \frac{1}{n_\ell} \sum_{k, m} \mathbb{E} \left[\sigma'_{m; \delta_0}(\ell) \sigma'_{k; \delta_1}(\ell) \sigma'_{k; \delta_2}(\ell) \sigma_{m; \delta}^{(\ell)} \widehat{\Delta H}_{m k k; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] \right\} \\
&+ O\left(\frac{1}{n^2}\right). \tag{11.40}
\end{aligned}$$

花括号内的因子实际上是一阶的, 因为正如第二层所见, 并将在下一步对一般层 ℓ 递归证明的那样, 领先的 dNTK-预激活量交叉相关为 $1/n$ 阶. 与此同时, 最后一个本应正比于 $\partial^3 \mathcal{O}$ 的项仍是次领先的:

$$\begin{aligned}
& (C_W^{(\ell+1)})^3 \sum_{\delta_3, \delta_4, \delta_5 \in \mathcal{D}} \left\langle \left\langle \frac{\partial^3 \mathcal{O}}{\partial z_{i_0; \delta_3}^{(\ell+1)} \partial z_{i_1; \delta_4}^{(\ell+1)} \partial z_{i_2; \delta_5}^{(\ell+1)}} \right\rangle \right\rangle_{K^{(\ell+1)}} \\
& \times \frac{1}{n_\ell^3} \sum_{k_0, k_1, k_2} \mathbb{E} \left[\left(\sigma'_{k_0; \delta_0}(\ell) \sigma_{k_0; \delta_3}^{(\ell)} \right) \left(\sigma'_{k_1; \delta_1}(\ell) \sigma_{k_1; \delta_4}^{(\ell)} \right) \left(\sigma'_{k_2; \delta_2}(\ell) \sigma_{k_2; \delta_5}^{(\ell)} \right) \widehat{\Delta H}_{k_0 k_1 k_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] = O\left(\frac{1}{n^2}\right). \tag{11.41}
\end{aligned}$$

这是因为期望本身是另一个 dNTK-预激活量交叉相关函数, 故至多为 $1/n$ 阶. 此外, 只有三个神经元指标 k_0, k_1, k_2 中有两个重合时, 才会得到这样的 $1/n$ 阶贡献; 从用 P - Q 分解计算此类交叉相关时出现的 Kronecker delta 模式即可看清这一点: 第二层见 (11.30), 更深层则可前看一段至 (11.42). 因而三重指标求和被限制为仅有两个独立求和; 计入前因子 $1/n^3$ 后, 该项的整体贡献按 $\sim (1/n^3)(n^2)(1/n) \sim 1/n^2$ 标度.

把已经算出的贡献 (11.37) (使用两次)、(11.38) 和 (11.40) 代入一般 dNTK-预激活量交叉相关表达式 (11.36), 得到

$$\begin{aligned}
& \mathbb{E} \left[\mathcal{O}(z^{(\ell+1)}) \widehat{\Delta H}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell+1)} \right] \\
&= \frac{1}{n_\ell} \sum_{\delta \in \mathcal{D}} \left[\delta_{i_1 i_2} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_0; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} P_{\delta_0 \delta_1 \delta_2 \delta}^{(\ell+1)} \right. \\
& \quad \left. + \delta_{i_0 i_1} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_2; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} Q_{\delta_0 \delta_1 \delta_2 \delta}^{(\ell+1)} + \delta_{i_0 i_2} \left\langle \left\langle \frac{\partial \mathcal{O}}{\partial z_{i_1; \delta}^{(\ell+1)}} \right\rangle \right\rangle_{G^{(\ell+1)}} Q_{\delta_0 \delta_2 \delta_1 \delta}^{(\ell+1)} \right] + O\left(\frac{1}{n^2}\right), \tag{11.42}
\end{aligned}$$

其中引入了第二层张量 $P^{(2)}$ (11.31) 和 $Q^{(2)}$ (11.32) 在第 $(\ell + 1)$ 层的推广:

$$P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} \equiv \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma_{m;\delta_0}''^{(\ell)} \sigma_{k;\delta_1}'^{(\ell)} \sigma_{k;\delta_2}'^{(\ell)} \sigma_{m;\delta_3}^{(\ell)} \widehat{H}_{mk;\delta_0 \delta_1}^{(\ell)} \widehat{H}_{mk;\delta_0 \delta_2}^{(\ell)} \right] \quad (11.43)$$

$$+ \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma_{m;\delta_0}'^{(\ell)} \sigma_{k;\delta_1}'^{(\ell)} \sigma_{k;\delta_2}'^{(\ell)} \sigma_{m;\delta_3}^{(\ell)} \widehat{dH}_{mk;\delta_0 \delta_1 \delta_2}^{(\ell)} \right] + O\left(\frac{1}{n}\right),$$

$$Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} \equiv \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma_{k;\delta_0}''^{(\ell)} \sigma_{k;\delta_1}'^{(\ell)} \sigma_{m;\delta_2}'^{(\ell)} \sigma_{m;\delta_3}^{(\ell)} \widehat{H}_{kk;\delta_0 \delta_1}^{(\ell)} \widehat{H}_{km;\delta_0 \delta_2}^{(\ell)} \right] + \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} F_{\delta_1 \delta_0 \delta_3 \delta_2}^{(\ell+1)} \\ + \left(C_W^{(\ell+1)}\right)^2 \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma_{k;\delta_0}'^{(\ell)} \sigma_{k;\delta_1}'^{(\ell)} \sigma_{m;\delta_2}'^{(\ell)} \sigma_{m;\delta_3}^{(\ell)} \widehat{dH}_{kkm;\delta_0 \delta_1 \delta_2}^{(\ell)} \right] + O\left(\frac{1}{n}\right). \quad (11.44)$$

为看出这些一般表达式如何约化为第二层的 $P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)}$ 和 $Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(2)}$, 即 (11.31) 和 (11.32), 回顾第一层 NTK 是确定性的且在神经元指标上对角, $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(1)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(1)}$; 第一层 dNTK 消失, $\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(1)} = 0$; 而第二层 NTK-预激活量交叉相关张量为 $F_{\delta_1 \delta_0 \delta_3 \delta_2}^{(2)} = \left(C_W^{(2)}\right)^2 H_{\delta_0 \delta_2}^{(1)} \langle \sigma_{\delta_1} \sigma_{\delta_3} \sigma_{\delta_0}' \sigma_{\delta_2}' \rangle_{G^{(1)}}$ (8.39).

最后, 把可观测量取为 $\mathcal{O} = z_{i_3; \delta_3}^{(\ell+1)}$, 便得到

$$\mathbb{E} \left[\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell+1)} z_{i_3; \delta_3}^{(\ell+1)} \right] = \frac{1}{n_\ell} \left[\delta_{i_0 i_3} \delta_{i_1 i_2} P_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} + \delta_{i_0 i_1} \delta_{i_2 i_3} Q_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} + \delta_{i_0 i_2} \delta_{i_1 i_3} Q_{\delta_0 \delta_2 \delta_1 \delta_3}^{(\ell+1)} \right]. \quad (11.45)$$

重要的是, 这意味着在 $1/n$ 的领先非零阶, 单个预激活量与基本 dNTK-预激活量交叉相关 (11.45) 的分解张量, 完全确定了更复杂可观测量的一般 dNTK-预激活量交叉相关 (11.42).²¹⁵ 因此, 为在分析中完整纳入 dNTK 的领先效应, 只需计算 $P^{(\ell)}$ 和 $Q^{(\ell)}$ 的递推.²¹⁶

P-递推

为求出 $P^{(\ell)}$ 的递推, 需要计算 (11.43) 中的两个期望.

对于第一个期望, 把 NTK 分解为均值与涨落, $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(\ell)} + \widehat{\Delta H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)}$,

²¹⁵换言之, 在所考虑的 $1/n$ 阶, 总可把任意期望中的第 ℓ 层 dNTK 替换为如下微分算子:

$$\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \rightarrow \frac{1}{n_{\ell-1}} \sum_{\delta \in \mathcal{D}} \left[\delta_{i_1 i_2} P_{\delta_0 \delta_1 \delta_2 \delta}^{(\ell)} \frac{\partial}{\partial z_{i_0; \delta}^{(\ell)}} + \delta_{i_0 i_1} Q_{\delta_0 \delta_1 \delta_2 \delta}^{(\ell)} \frac{\partial}{\partial z_{i_2; \delta}^{(\ell)}} + \delta_{i_0 i_2} Q_{\delta_0 \delta_2 \delta_1 \delta}^{(\ell)} \frac{\partial}{\partial z_{i_1; \delta}^{(\ell)}} \right], \quad (11.46)$$

其中 $P^{(\ell)}$ 和 $Q^{(\ell)}$ 是无涨落的系数. 使用这一替换时, 必须记住导数作用于所有乘在 dNTK 上的第 ℓ 层预激活量; 也就是说, 作此替换前应把 dNTK 一直移到期望的最左端.

²¹⁶任何预激活量-NTK-dNTK 交叉相关, 例如 $\mathbb{E} \left[\widehat{\Delta H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} \widehat{dH}_{i_3 i_4 i_5; \delta_3 \delta_4 \delta_5}^{(\ell)} z_{i_6; \delta_6}^{(\ell)} \right]$, 以及任何更高阶 dNTK 相关函数, 例如 $\mathbb{E} \left[\widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \widehat{dH}_{i_3 i_4 i_5; \delta_3 \delta_4 \delta_5}^{(\ell)} \right]$, 都是次领先的. 这里不作显式证明, 但读者若自行推导, 或许会更为安心; 这两个例子在第二层 $L = 2$ 都相对容易算出.

得到

$$\begin{aligned} & \frac{1}{n_\ell^2} \sum_{k,m} \mathbb{E} \left[\sigma''_{m;\delta_0}(\ell) \sigma'_{k;\delta_1}(\ell) \sigma'_{k;\delta_2}(\ell) \sigma_{m;\delta_3}(\ell) \widehat{H}_{mk;\delta_0\delta_1}^{(\ell)} \widehat{H}_{mk;\delta_0\delta_2}^{(\ell)} \right] \\ &= \frac{1}{n_\ell} \langle \sigma''_{\delta_0} \sigma'_{\delta_1} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} H_{\delta_0\delta_1}^{(\ell)} H_{\delta_0\delta_2}^{(\ell)} + \frac{1}{n_{\ell-1}} \langle \sigma''_{\delta_0} \sigma_{\delta_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{G^{(\ell)}} B_{\delta_0\delta_0\delta_1\delta_2}^{(\ell)} + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (11.47)$$

特别地，由一个 NTK 均值和一个 NTK 涨落组成的交叉项消失了：均值带来的 Kronecker delta 限制了二重求和，而涨落又额外给出 $1/n$ 抑制。如果这一解释略显仓促，可以回顾从 (8.83) 到 (8.89) 对 B -递推所作的较慢推导；除样本指标和导数的位置不同外，其形式与上面的 (11.47) 完全相同。

对于 (11.43) 中的第二个期望，只需对第 ℓ 层应用一般交叉相关公式 (11.42)，从而将其化简为

$$\begin{aligned} & \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma'_{m;\delta_0}(\ell) \sigma'_{k;\delta_1}(\ell) \sigma'_{k;\delta_2}(\ell) \sigma_{m;\delta_3}(\ell) \widehat{dH}_{mk;\delta_0\delta_1\delta_2}^{(\ell)} \right] \\ &= \frac{1}{n_\ell n_{\ell-1}} \sum_{k,m=1}^{n_\ell} \sum_{\delta_4 \in \mathcal{D}} \left[\left\langle \left\langle \frac{\partial}{\partial z_{m;\delta_4}} \left(\sigma'_{m;\delta_0}(\ell) \sigma'_{k;\delta_1}(\ell) \sigma'_{k;\delta_2}(\ell) \sigma_{m;\delta_3}(\ell) \right) \right\rangle_{G^{(\ell)}} \right\rangle_{G^{(\ell)}} P_{\delta_0\delta_1\delta_2\delta_4}^{(\ell)} + \delta_{mk} \times O(1) \right] + O\left(\frac{1}{n}\right) \\ &= \left(\frac{n_\ell}{n_{\ell-1}} \right) \left[\langle \sigma''_{\delta_0} \sigma_{\delta_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{G^{(\ell)}} P_{\delta_0\delta_1\delta_2\delta_0}^{(\ell)} + \langle \sigma'_{\delta_0} \sigma'_{\delta_3} \rangle_{K^{(\ell)}} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{K^{(\ell)}} P_{\delta_0\delta_1\delta_2\delta_3}^{(\ell)} \right] + O\left(\frac{1}{n}\right). \end{aligned} \quad (11.48)$$

在第二行中，我们只是把正比于 δ_{mk} 的 $Q^{(\ell)}$ 项写成 $O(1)$ ；这些项的细节并不重要，因为在约束 $m = k$ 下执行二重求和时，它们是次领先的。对于正比于 $P^{(\ell)}$ 的项， $k = m$ 的对角贡献同样是次领先的；领先贡献来自 $k \neq m$ 的 $(n_\ell^2 - n_\ell)$ 个非对角部分。此时导数只作用在四个激活函数中的两个上，继而可用高斯因子分解把每一项写成单神经元高斯期望的乘积。

把这两个化简后的期望代回 $P^{(\ell+1)}$ 的表达式 (11.43)，得到递推：

$$\begin{aligned} P_{\delta_0\delta_1\delta_2\delta_3}^{(\ell+1)} &= \left(C_W^{(\ell+1)} \right)^2 \langle \sigma''_{\delta_0} \sigma'_{\delta_1} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} H_{\delta_0\delta_1}^{(\ell)} H_{\delta_0\delta_2}^{(\ell)} \\ &\quad + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{G^{(\ell)}} \\ &\quad \times \left[\langle \sigma''_{\delta_0} \sigma_{\delta_3} \rangle_{G^{(\ell)}} P_{\delta_0\delta_1\delta_2\delta_0}^{(\ell)} + \langle \sigma'_{\delta_0} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} P_{\delta_0\delta_1\delta_2\delta_3}^{(\ell)} + \langle \sigma''_{\delta_0} \sigma_{\delta_3} \rangle_{G^{(\ell)}} B_{\delta_0\delta_0\delta_1\delta_2}^{(\ell)} \right] + O\left(\frac{1}{n}\right). \end{aligned} \quad (11.49)$$

有趣的是，这个 dNTK 张量 $P^{(\ell)}$ 同时与 NTK 均值 $H^{(\ell)}$ 和 NTK 方差张量 $B^{(\ell)}$ 混合。由于 $H^{(\ell)}$ 与 $B^{(\ell)}$ 都是一阶的，且 $P^{(1)} = 0$ ，这一递推表明 $P^{(\ell)}$ 会递归地在所有层 ℓ 中保持一阶。

Q-递推

为求出 $Q^{(\ell)}$ 的递推，需要计算 (11.44) 中的两个期望。

对于第一个期望，再次把 NTK 分解成均值与涨落， $\widehat{H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} = \delta_{i_1 i_2} H_{\delta_1 \delta_2}^{(\ell)} + \widehat{\Delta H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)}$ ，

得到

$$\begin{aligned}
& \frac{1}{n_\ell^2} \sum_{k,m} \mathbb{E} \left[\sigma''_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{m;\delta_2} \sigma_{m;\delta_3} \widehat{H}_{kk;\delta_0\delta_1}^{(\ell)} \widehat{H}_{km;\delta_0\delta_2}^{(\ell)} \right] \\
&= \frac{1}{n_\ell^2} \sum_k \mathbb{E} \left[\sigma''_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{k;\delta_2} \sigma_{k;\delta_3} \right] H_{\delta_0\delta_1}^{(\ell)} H_{\delta_0\delta_2}^{(\ell)} + \frac{1}{n_\ell^2} \sum_k \mathbb{E} \left[\sigma_{k;\delta_3}^{(\ell)} \sigma''_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{k;\delta_2} \widehat{\Delta H}_{kk;\delta_0\delta_1}^{(\ell)} \right] H_{\delta_0\delta_2}^{(\ell)} \\
&\quad + \frac{1}{n_\ell^2} \sum_{k,m} \mathbb{E} \left[\sigma''_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{m;\delta_2} \sigma_{m;\delta_3} \widehat{\Delta H}_{km;\delta_0\delta_2}^{(\ell)} \right] H_{\delta_0\delta_1}^{(\ell)} \\
&\quad + \frac{1}{n_\ell^2} \sum_{k,m} \mathbb{E} \left[\sigma''_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{m;\delta_2} \sigma_{m;\delta_3} \widehat{\Delta H}_{kk;\delta_0\delta_1}^{(\ell)} \widehat{\Delta H}_{km;\delta_0\delta_2}^{(\ell)} \right] \\
&= \frac{1}{n_\ell} \langle \sigma''_{\delta_0} \sigma'_{\delta_1} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} H_{\delta_0\delta_1}^{(\ell)} H_{\delta_0\delta_2}^{(\ell)} \\
&\quad + \frac{1}{n_{\ell-1}} \sum_{\delta_4, \delta_5, \delta_6, \delta_7} H_{\delta_0\delta_1}^{(\ell)} \langle z_{\delta_4} \sigma''_{\delta_0} \sigma'_{\delta_1} \rangle_{G^{(\ell)}} \langle z_{\delta_5} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_4\delta_6} G_{(\ell)}^{\delta_5\delta_7} F_{\delta_6\delta_0\delta_7\delta_2}^{(\ell)} + O\left(\frac{1}{n^2}\right).
\end{aligned} \tag{11.50}$$

这里，从第二个表达式过渡到第三个表达式需要计算四个期望：第一个期望在领先阶给出单神经元高斯期望；第二个期望是次领先的，参见 (8.71)；第三个期望也可用同一个一般 NTK-预激活量交叉相关公式 (8.71) 计算，但在此给出正比于 $F^{(\ell)}$ 的领先项；最后一个期望则因未配对的神经元指标 m 而消失，参见 (8.87) 中的类似处理以及随后的分解 (8.82)。

为化简 (11.44) 中的第二个期望，可再次对第 ℓ 层应用一般交叉相关公式 (11.42)：

$$\begin{aligned}
& \frac{1}{n_\ell} \sum_{k,m=1}^{n_\ell} \mathbb{E} \left[\sigma'_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{m;\delta_2} \sigma_{m;\delta_3} \widehat{dH}_{kkm;\delta_0\delta_1\delta_2}^{(\ell)} \right] \\
&= \frac{1}{n_\ell n_{\ell-1}} \sum_{k,m=1}^{n_\ell} \sum_{\delta_4 \in \mathcal{D}} \left[\left\langle \left\langle \frac{\partial}{\partial z_{m;\delta_4}} \left(\sigma'_{k;\delta_0} \sigma'_{k;\delta_1} \sigma'_{m;\delta_2} \sigma_{m;\delta_3} \right) \right\rangle \right\rangle_{G^{(\ell)}} Q_{\delta_0\delta_1\delta_2\delta_4}^{(\ell)} \right] + O\left(\frac{1}{n}\right) \\
&= \left(\frac{n_\ell}{n_{\ell-1}} \right) \left[\langle \sigma''_{\delta_2} \sigma_{\delta_3} \rangle_{K^{(\ell)}} \langle \sigma'_{\delta_0} \sigma'_{\delta_1} \rangle_{G^{(\ell)}} Q_{\delta_0\delta_1\delta_2\delta_2}^{(\ell)} + \langle \sigma'_{\delta_2} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \rangle_{G^{(\ell)}} Q_{\delta_0\delta_1\delta_2\delta_3}^{(\ell)} \right] + O\left(\frac{1}{n}\right).
\end{aligned} \tag{11.51}$$

在第二行中，这一次甚至没有写出正比于 δ_{mk} 的项；正如计算 P -递推时已经看到的，二重求和中的约束 $k = m$ 会使这些项成为次领先的。在最后一个等式中，同样类似于 P -递推，我们保留 $k \neq m$ 的非对角项，取导数，使用高斯因子分解，并执行二重求和。

把这两个化简后的期望代回 $Q^{(\ell+1)}$ 的表达式 (11.44)，便得到本书最后一个递推：

$$\begin{aligned}
Q_{\delta_0\delta_1\delta_2\delta_3}^{(\ell+1)} &= \left(C_W^{(\ell+1)} \right)^2 \langle \sigma''_{\delta_0} \sigma'_{\delta_1} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} H_{\delta_0\delta_1}^{(\ell)} H_{\delta_0\delta_2}^{(\ell)} + \frac{\lambda_W^{(\ell+1)}}{C_W^{(\ell+1)}} F_{\delta_1\delta_0\delta_3\delta_2}^{(\ell+1)} \\
&\quad + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 \langle \sigma'_{\delta_0} \sigma'_{\delta_1} \rangle_{G^{(\ell)}} \left[\langle \sigma''_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_0\delta_1\delta_2\delta_2}^{(\ell)} + \langle \sigma'_{\delta_2} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_0\delta_1\delta_2\delta_3}^{(\ell)} \right] \\
&\quad + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 H_{\delta_0\delta_1}^{(\ell)} \sum_{\delta_4, \dots, \delta_7 \in \mathcal{D}} \langle z_{\delta_4} \sigma''_{\delta_0} \sigma'_{\delta_1} \rangle_{G^{(\ell)}} \langle z_{\delta_5} \sigma'_{\delta_2} \sigma_{\delta_3} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_4\delta_6} G_{(\ell)}^{\delta_5\delta_7} F_{\delta_6\delta_0\delta_7\delta_2}^{(\ell)} \\
&\quad + O\left(\frac{1}{n}\right).
\end{aligned} \tag{11.52}$$

有趣的是，在这种情况下，dNTK 张量 $Q^{(\ell)}$ 同时与 NTK 均值 $H^{(\ell)}$ 以及 NTK-预激活量交叉相关张量 $F^{(\ell)}$ 混合。²¹⁷ 同样，由于 $H^{(\ell)}$ 和 $F^{(\ell)}$ 都是一阶的，且 $Q^{(1)} = 0$ ，这一

²¹⁷另一点也可能值得注意： $F^{(\ell)}$ 的递推 (8.79) 和 $B^{(\ell)}$ 的递推 (8.89) 由 NTK 均值 $H^{(\ell)}$ 驱动，但除此

递推表明 $Q^{(\ell)}$ 也会递归地在所有层 ℓ 中保持一阶。

总之, 结合一般 dNTK-预激活量交叉相关公式 (11.42), P - Q 递推 (11.49) 和 (11.52) 表明, 领先的 dNTK-预激活量交叉相关受到 $1/n$ 抑制. 换言之, dNTK 的效应仅在有限宽度下可见.

11.3 初始化时 dNTK 的有效理论

本节与我们先前关于预激活量统计以及 NTK-预激活量联合统计的有效理论工作相对应 (§5 || §9). 特别地, 由于我们已经知道临界性为何至关重要的诸多不同理由, 参见 §5、§6、§9 和 §10, 这里将少花些篇幅讨论不选择临界初始化超参数的灾难性后果, 而把更多精力用于寻找临界处 P -递推与 Q -递推的渐近解.

如同讨论 §5 中的预激活量临界性和 §9 中的 NTK 临界性时那样, 本节始终令偏置方差 $C_b^{(\ell)}$ 与重标度权重方差 $C_W^{(\ell)}$ 在各层上一致:

$$C_b^{(\ell)} = C_b, \quad C_W^{(\ell)} = C_W. \quad (11.53)$$

进一步仿照 §5.4 和 §9.1–§9.3, 我们考虑所有隐藏层宽度相同的 MLP:

$$n_1 = \dots = n_{L-1} \equiv n. \quad (11.54)$$

最后, 与 §9 类似, 我们只关注单输入统计, 而把多输入递推的求值留作一场寻求刺激者的冒险.²¹⁸

作出这些选择后, 写下 $P^{(\ell)}$ 和 $Q^{(\ell)}$ 的领先单输入递推. 略去样本指标和在 $1/n$ 下次领先的贡献, 特别是以核替代均值度量 $G^{(\ell)} \rightarrow K^{(\ell)}$ 、以冻结 NTK 替代 NTK 均值 $H^{(\ell)} \rightarrow \Theta^{(\ell)}$, 递推 (11.49) 和 (11.52) 化为

$$\begin{aligned} P^{(\ell+1)} = & C_W^2 \langle \sigma'' \sigma' \sigma' \sigma \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^2 + C_W \chi_{\perp}^{(\ell)} \langle \sigma'' \sigma \rangle_{K^{(\ell)}} B^{(\ell)} \\ & + \left[C_W \chi_{\perp}^{(\ell)} \langle \sigma'' \sigma \rangle_{K^{(\ell)}} + \left(\chi_{\perp}^{(\ell)} \right)^2 \right] P^{(\ell)}, \end{aligned} \quad (11.55)$$

$$\begin{aligned} Q^{(\ell+1)} = & C_W^2 \langle \sigma'' \sigma' \sigma' \sigma \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^2 + \frac{\lambda_W^{(\ell+1)}}{C_W} F^{(\ell+1)} + 2h^{(\ell)} \chi_{\parallel}^{(\ell)} \Theta^{(\ell)} F^{(\ell)} \\ & + \left[C_W \chi_{\perp}^{(\ell)} \langle \sigma'' \sigma \rangle_{K^{(\ell)}} + \left(\chi_{\perp}^{(\ell)} \right)^2 \right] Q^{(\ell)}, \end{aligned} \quad (11.56)$$

初始条件为 (参见 §11.2.1)

$$P^{(1)} = Q^{(1)} = 0. \quad (11.57)$$

之外不与任何有限宽度张量混合; NTK-预激活量交叉相关张量 $D^{(\ell)}$ 的递推 (8.77) 则与四点顶角 $V^{(\ell)}$ 混合, 而 NTK 方差张量 $A^{(\ell)}$ 的递推 (8.97) 同时与 $V^{(\ell)}$ 和 $D^{(\ell)}$ 混合. 因而至少在这一阶, $F^{(\ell)}$ 和 $B^{(\ell)}$ 类型的相关与涨落可能有助于 dNTK 所诱导的表征学习, 而 $V^{(\ell)}$ 、 $D^{(\ell)}$ 和 $A^{(\ell)}$ 或许更多地与不同实例之间的涨落有关.

²¹⁸需要把 $\gamma^{[a]}$ 推广成张量积 $\gamma^{[a]} \otimes \gamma^{[b]}$, 再根据所要展开的有限宽度张量的对称性进一步分解这一基底.

为简化这些表达式，我们回顾两个易感率，即平行易感率 (5.50) 和垂直易感率 (5.51)：

$$\chi_{\parallel}^{(\ell)} \equiv \frac{C_W}{K^{(\ell)}} \langle \sigma' \sigma z \rangle_{K^{(\ell)}} , \quad (11.58)$$

$$\chi_{\perp}^{(\ell)} \equiv C_W \langle \sigma' \sigma' \rangle_{K^{(\ell)}} , \quad (11.59)$$

并且还回顾我们最不喜欢的辅助函数 (5.52)：

$$h^{(\ell)} \equiv \frac{1}{2} \frac{d}{dK^{(\ell)}} \chi_{\perp}^{(\ell)} = \frac{C_W}{2K^{(\ell)}} \langle \sigma'' \sigma' z \rangle_{K^{(\ell)}} , \quad (11.60)$$

不过，右端给出了一个通过分部积分得到的新表达式，参见 (5.53)。

为了在临界处求解这些递推，需要回顾可观测量的标度假设 (5.93)：

$$\mathcal{O}^{(\ell)} = \left(\frac{1}{\ell} \right)^{p_{\mathcal{O}}} \left[c_{0,0} + c_{1,1} \left(\frac{\log \ell}{\ell} \right) + c_{1,0} \left(\frac{1}{\ell} \right) + c_{2,2} \left(\frac{\log^2 \ell}{\ell^2} \right) + \dots \right] . \quad (11.61)$$

在这里，求解 dNTK 递推将给出新的临界指数 p_P 和 p_Q ，它们分别描述 $P^{(\ell)}$ 和 $Q^{(\ell)}$ 的渐近深度标度。

此外，为理解 dNTK-预激活量交叉相关的相对大小，需要像先前在 §5.4 和 §9.1 中那样找出适当的无量纲量。在此情形下，应当用两个（冻结）NTK 因子归一化：

$$\frac{P^{(\ell)}}{n(\Theta^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_P - 2p_{\Theta}} , \quad \frac{Q^{(\ell)}}{n(\Theta^{(\ell)})^2} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_Q - 2p_{\Theta}} , \quad (11.62)$$

其中右端的 p_{Θ} 是冻结 NTK 的临界指数。

要看出为何应考虑这些量，回顾 §1.3 的脚注 16 中对量纲分析的讨论，以及记号 $[z]$ 表示“ z 以 $[z]$ 为单位度量”。考察 (11.9) 中预激活量的二阶更新，并记住只有量纲相同的项才能相加，必有

$$[z] = [\eta] [\epsilon] [\widehat{H}] = [\eta]^2 [\epsilon]^2 [\widehat{dH}] , \quad (11.63)$$

由此显然有 $[\eta] [\epsilon] = [z] [\widehat{H}]^{-1}$ ，进而可见 P 和 Q 的量纲都是 NTK 的平方：

$$[P] = [Q] \equiv [z] [\widehat{dH}] = [\widehat{H}]^2 . \quad (11.64)$$

如果这仍显得有些违反直觉，那么当我们在 §∞.2.3 中分析完全训练后的有限宽度网络的随机预测时，考虑 (11.62) 中这些特定比值的用处将变得更加明显。

在两个普适类中求解 P -递推和 Q -递推，并考察无量纲量 (11.62) 后，我们会再次发现超越普适类的标度律：

$$p_P - 2p_{\Theta} = -1 , \quad p_Q - 2p_{\Theta} = -1 . \quad (11.65)$$

具体而言，我们将看到这些定律对尺度不变普适类和 $K^* = 0$ 普适类均成立。²¹⁹ 因此可以断定，预激活量-NTK-dNTK 联合分布的所有领先有限宽度效应，在 RG 流的意义下都是相关的，并受同一个 ℓ/n 微扰截断控制。

现在准备工作已经齐全，下面实际求解这两个重要普适类中的 dNTK 递推。

²¹⁹更确切地说，对于尺度不变类，我们将发现 $P^{(\ell)}$ 恒等于零，而 $Q^{(\ell)}$ 独自决定领先的有限宽度 dNTK-预激活量交叉相关。

11.3.1 尺度不变普适类

首先回顾计算递推 (11.55) 和 (11.56) 所需的若干先前结果. 对于尺度不变普适类, 由 (5.62)、(9.33) 和 (9.37) 可知

$$\chi_{\perp}^{(\ell)} = C_W A_2 \equiv \chi, \quad h^{(\ell)} = 0, \quad \langle \sigma' \sigma' \sigma \sigma \rangle_{K^{(\ell)}} = A_4 K^{(\ell)}, \quad (11.66)$$

其中回顾一下, $A_2 \equiv (a_+^2 + a_-^2)/2$ 、 $A_4 \equiv (a_+^4 + a_-^4)/2$, 而 $a_{\pm}$ 分别是激活函数正、负线性部分的斜率, 参见 (5.59).

接着可以看到, 递推 (11.55) 和 (11.56) 中所有新的高斯期望都涉及激活函数的二阶导数. 对于非线性尺度不变激活函数, 需要稍加小心, 因为它们在原点有一个不可微的折点. (对于线性激活函数, $\sigma''(z) = 0$, 不存在这一微妙之处.) 对第一个新期望作分部积分, 得到

$$\langle \sigma'' \sigma \rangle_K = \frac{1}{\sqrt{2\pi K}} \int_{-\infty}^{\infty} dz e^{-\frac{z^2}{2K}} \left(\frac{d}{dz} \sigma' \right) \sigma = \frac{1}{K} \langle z \sigma' \sigma \rangle_K - \langle \sigma' \sigma' \rangle_K = 0, \quad (11.67)$$

最后一个等号使用了

$$\frac{1}{K} \langle z \sigma' \sigma \rangle_K = \langle \sigma' \sigma' \rangle_K = A_2. \quad (11.68)$$

类似地, 对另一个新的高斯期望作分部积分, 得到

$$\langle \sigma'' \sigma' \sigma' \sigma \rangle_K = \frac{1}{K} \langle z \sigma' \sigma' \sigma' \sigma \rangle_K - 2 \langle \sigma'' \sigma' \sigma' \sigma \rangle_K - \langle \sigma' \sigma' \sigma' \sigma' \rangle_K. \quad (11.69)$$

重新整理便容易看出

$$\langle \sigma'' \sigma' \sigma' \sigma \rangle_K = \frac{1}{3K} \langle z \sigma' \sigma' \sigma' \sigma \rangle_K - \frac{1}{3} \langle \sigma' \sigma' \sigma' \sigma' \rangle_K = 0, \quad (11.70)$$

其中最后一个等号使用了

$$\frac{1}{K} \langle z \sigma' \sigma' \sigma' \sigma \rangle_K = \langle \sigma' \sigma' \sigma' \sigma' \rangle_K = A_4. \quad (11.71)$$

因此可以放心忽略这两个新期望.

代入 (11.66) 中的所有结果并略去可忽略的期望, 单输入递推 (11.55) 和 (11.56) 变得极其简单:

$$P^{(\ell+1)} = \chi^2 P^{(\ell)}, \quad (11.72)$$

$$Q^{(\ell+1)} = \chi^2 Q^{(\ell)} + \frac{\lambda_W^{(\ell+1)}}{C_W} F^{(\ell+1)}. \quad (11.73)$$

特别地, 由于初始条件 (11.57) 是 $P^{(1)} = 0$, 立即可见 $P^{(\ell)}$ 在所有层上恒等于零:

$$P^{(\ell)} = 0. \quad (11.74)$$

相反, 对于 $Q^{(\ell)}$, 易感率 χ 一般会导致指数行为.

现在令初始化超参数为 $C_b = 0$ 和 $C_W = 1/A_2$, 从而调谐到尺度不变临界性. 其结果是易感率固定为一, $\chi = 1$, 而所有层上的核均固定为 $K^{(\ell)} = K^*$. 此外, 按照学习率等价原理选择训练超参数; 该原理要求采用 (9.94) 中与层无关的学习率:

$$\lambda_b^{(\ell)} = \frac{\tilde{\lambda}_b}{L}, \quad \lambda_W^{(\ell)} = \frac{\tilde{\lambda}_W}{L}. \quad (11.75)$$

最后, 在这些超参数选择下, 冻结 NTK 的单输入解 (9.44) 和 NTK-预激活量交叉相关 $F^{(\ell)}$ 的单输入解 (9.50) 分别为

$$\Theta^{(\ell)} = \left(\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K^* \right) \frac{\ell}{L}, \quad (11.76)$$

$$F^{(\ell)} = \frac{\ell(\ell-1)}{2L} \left[\frac{A_4}{A_2^2} \left(\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K^* \right) K^* \right]. \quad (11.77)$$

把临界初始化超参数、固定核、学习率 (11.75) 以及 $F^{(\ell)}$ 的表达式 (11.77) 代入, Q -递推 (11.73) 变成

$$Q^{(\ell+1)} = Q^{(\ell)} + \frac{\ell(\ell+1)}{2L^2} \left[\frac{A_4}{A_2} \left(\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K^* \right) \tilde{\lambda}_W K^* \right]. \quad (11.78)$$

这个简单递推的精确解为

$$Q^{(\ell)} = \frac{\ell(\ell^2-1)}{6L^2} \left[\frac{A_4}{A_2} \left(\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K^* \right) \tilde{\lambda}_W K^* \right], \quad (11.79)$$

它满足初始条件 $Q^{(1)} = 0$.

利用这个解, 可以辨认出与 $Q^{(\ell)}$ 的大 ℓ 行为相联系的临界指数: $p_Q = -3$. 此外, 正如所承诺的, 无量纲量 (11.62) 满足标度律 (11.65):

$$p_Q - 2p_\Theta = -1, \quad (11.80)$$

这里还使用了上面 (11.76) 中重列的尺度不变冻结 NTK 解所给出的 $p_\Theta = -1$. 更具体地, 把 $\Theta^{(\ell)}$ 的解 (11.76) 和 $Q^{(\ell)}$ 的解 (11.79) 代入无量纲比值 (11.62), 得到

$$\frac{Q^{(\ell)}}{n(\Theta^{(\ell)})^2} = \frac{A_4}{6A_2} \left[\frac{\tilde{\lambda}_W K^*}{\tilde{\lambda}_b + \tilde{\lambda}_W A_2 K^*} \right] \frac{\ell}{n} + \dots \quad (11.81)$$

因此, 我们验证了尺度不变激活函数的领先 dNTK-预激活量交叉相关具有 ℓ/n 标度.

11.3.2 $K^* = 0$ 普适类

对于 $K^* = 0$ 普适类, 我们同样先回顾若干先前结果. 首先, 由 (5.84)、(5.85)、(9.64) 和 (11.60) 可知

$$\chi_{\parallel}(K) = (C_W \sigma_1^2) [1 + 2a_1 K + O(K^2)], \quad (11.82)$$

$$\chi_{\perp}(K) = (C_W \sigma_1^2) [1 + b_1 K + O(K^2)], \quad (11.83)$$

$$C_W^2 \langle \sigma' \sigma' \sigma \sigma \rangle_K = (C_W \sigma_1^2)^2 [K + O(1(K^2))], \quad (11.84)$$

$$h(K) = \frac{1}{2} \frac{d}{dK} \chi_{\perp}(K) = (C_W \sigma_1^2) \left[\frac{b_1}{2} + O(K^1) \right]. \quad (11.85)$$

为解释这些结果，回顾我们把激活函数 Taylor 展开为

$$\sigma(z) = \sum_{p=0}^{\infty} \frac{\sigma_p}{p!} z^p, \quad (11.86)$$

并为方便起见定义了如下 Taylor 系数组合：

$$a_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \frac{3}{4} \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (11.87)$$

$$b_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (11.88)$$

并要求此类中的所有激活函数满足 $\sigma_0 = 0$ 和 $\sigma_1 \neq 0$. 随后作类似的 Taylor 展开并逐阶执行高斯积分，可将递推 (11.55) 和 (11.56) 中的新高斯期望求为

$$C_W \langle \sigma'' \sigma \rangle_K = (C_W \sigma_1^2) [(2a_1 - b_1)K + O(K^2)], \quad (11.89)$$

$$C_W^2 \langle \sigma'' \sigma' \sigma' \sigma \rangle_K = (C_W \sigma_1^2)^2 [(-6a_1 + 7b_1)K + O(K^2)]. \quad (11.90)$$

现在令初始化超参数为 $C_b = 0$ 和 $C_W = 1/\sigma_1^2$ ，直接进入 $K^* = 0$ 临界性 (5.90). 同时还按照学习率等价原理调谐训练超参数；对于 $K^* = 0$ 激活函数，该原理由 (9.95) 给出：

$$\lambda_b^{(\ell)} = \tilde{\lambda}_b \left(\frac{1}{\ell} \right)^{p_{\perp}} L^{p_{\perp}-1}, \quad \lambda_W^{(\ell)} = \tilde{\lambda}_W \left(\frac{L}{\ell} \right)^{p_{\perp}-1}, \quad (11.91)$$

其中垂直微扰的临界指数定义为 $p_{\perp} \equiv b_1/a_1$. 在这些超参数设定下，再记录递推所需的其它单输入解，即核 $K^{(\ell)}$ (5.92)、冻结 NTK $\Theta^{(\ell)}$ (9.71)、NTK-预激活量交叉相关 $F^{(\ell)}$ (9.81) 和 NTK 方差 $B^{(\ell)}$ (9.82)：

$$K^{(\ell)} = \left[\frac{1}{(-a_1)} \right] \frac{1}{\ell} + \dots, \quad (11.92)$$

$$\Theta^{(\ell)} = \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{L}{\ell} \right)^{p_{\perp}-1} + \dots, \quad (11.93)$$

$$F^{(\ell)} = \frac{1}{(5 - p_{\perp})} \left[\frac{1}{(-a_1)} \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{L}{\ell} \right)^{p_{\perp}-1} + \dots, \quad (11.94)$$

$$B^{(\ell)} = \frac{L^{2p_{\perp}-2}}{3} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_{\perp}-3} + \dots. \quad (11.95)$$

最后，收集上述所有结果以及调谐 (11.82)–(11.85) 和 (11.89)–(11.95). 将它们代入 P -递推 (11.55) 和 Q -递推 (11.56)，得到

$$P^{(\ell+1)} = \left[1 - \frac{(p_{\perp} + 2)}{\ell} + \dots \right] P^{(\ell)} + \frac{(p_{\perp} - 2)}{3} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{L}{\ell} \right)^{2p_{\perp}-2} + \dots, \quad (11.96)$$

$$Q^{(\ell+1)} = \left[1 - \frac{(p_{\perp} + 2)}{\ell} + \dots \right] Q^{(\ell)} + \frac{1}{(5 - p_{\perp})} \left[(1 - p_{\perp}) \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} - p_{\perp} \tilde{\lambda}_b \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right] \left(\frac{L}{\ell} \right)^{2p_{\perp}-2} + \dots. \quad (11.97)$$

先处理 P -递推. 把标度假设 (11.61) 代入递推 (11.96) 并匹配各项, 得到渐近解

$$P^{(\ell)} = -\frac{L^{2p_{\perp}-2}}{3} \left(\frac{2-p_{\perp}}{5-p_{\perp}} \right) \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_{\perp}-3} + \dots \quad (11.98)$$

因此, 这一 dNTK-预激活量交叉相关的临界指数为 $p_P = 2p_{\perp} - 3$; 代入 $K^* = 0$ 冻结 NTK 解 (11.93) 给出的 $p_{\Theta} = p_{\perp} - 1$ 后, 便得到所承诺的标度律 (11.65):

$$p_P - 2p_{\Theta} = -1, \quad (11.99)$$

更具体地, 把 $\Theta^{(\ell)}$ 的解 (11.93) 和 $P^{(\ell)}$ 的解 (11.98) 代入无量纲比值 (11.62), 得到

$$\frac{P^{(\ell)}}{n(\Theta^{(\ell)})^2} = -\frac{1}{3} \left(\frac{2-p_{\perp}}{5-p_{\perp}} \right) \frac{\ell}{n} + \dots, \quad (11.100)$$

它 (i) 按 ℓ/n 标度, (ii) 与训练超参数无关, 并且在 $p_{\perp} \leq 1$ 时 (iii) 显然为负.²²⁰

类似地, 对于 Q -递推 (11.97), 最后一次把标度假设 (11.61) 代入递推 (11.97) 并匹配各项, 得到

$$Q^{(\ell)} = \frac{L^{2p_{\perp}-2}}{(5-p_{\perp})^2} \left[1 - p_{\perp} - \frac{\tilde{\lambda}_b}{\tilde{\lambda}_b + \tilde{\lambda}_W \sigma_1^2 / (-a_1)} \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W \sigma_1^2}{(-a_1)} \right]^2 \left(\frac{1}{\ell} \right)^{2p_{\perp}-3}. \quad (11.101)$$

这给出临界指数 $p_Q = 2p_{\perp} - 3$, 以及无量纲比值

$$\frac{Q^{(\ell)}}{n(\Theta^{(\ell)})^2} = \frac{1}{(5-p_{\perp})^2} \left[1 - p_{\perp} - \frac{\tilde{\lambda}_b}{\tilde{\lambda}_b + \tilde{\lambda}_W \sigma_1^2 / (-a_1)} \right] \frac{\ell}{n} + \dots \quad (11.102)$$

因此, 我们已经完整验证了标度律 (11.65):

$$p_Q - 2p_{\Theta} = -1. \quad (11.103)$$



总之, 在有限宽度展开的领先阶, 所有非零的无量纲 dNTK-预激活量交叉相关都会按 ℓ/n 增长. 由于 dNTK 会导致动态 NTK, 这足以说明深的有限宽度网络是表征学习器.

下一节将暂时搁置对深 MLP 的直接研究, 转而聚焦一个直接纳入非零 dNTK 效应的表征学习教学模型. 下一章中, 我们将回到有限宽度网络, 并完成计算训练后宽而深的有限宽度 MLP 上有效分布的目标. 下一节给出的简化模型将使后续对这种完全训练网络的分析结果更易理解.

²²⁰要回顾为何 $p_{\perp} \leq 1$, 而不必翻回 §10 的脚注 190, 可以依次注意: (i) 为使核 $K^{(\ell)}$ 在渐近趋近 $K^* = 0$ 不动点时保持为正, 必须有 $a_1 < 0$, 参见 (11.92); (ii) 有 $b_1 \geq a_1$, 参见 (11.87) 和 (11.88); (iii) $a_1 < 0$ 与 $b_1 \geq a_1$ 共同蕴含 $p_{\perp} \equiv b_1/a_1 \leq 1$.

11.4 非线性模型与近核方法

在 §10.4 中，我们把无限宽度网络置于更广泛的机器学习模型背景下。在那里，我们讨论了无限宽度网络既可以理解为具有固定随机特征的线性模型，也可以对偶地理解为一种核方法，其核由冻结 NTK 给出。现在，我们已经准备好为有限宽度网络寻找一个更广泛的背景。

本章已经看到，计算有限宽度网络动力学所需的统计量 (§11.2 和 §11.3) 远比无限宽度网络复杂，其中以非平凡方式纳入了网络函数的二阶导数。这种额外的复杂性不可约地浓缩在单一对象 dNTK (§11.1) 之中。dNTK 使 NTK 能够在训练过程中演化，从而由训练数据产生非平凡的表征学习。

本节的目标是把这一性质从深度学习框架中抽象出来，将其提炼为一个**表征学习的最小模型**，同时捕捉它的全部重要特征。这样的模型为研究深度神经网络所呈现的表征学习类型提供了一个更简洁、也更广泛的框架。换言之，我们希望这项工作能够扩展机器学习的标准工具箱。

首先，在 §11.4.1 中，我们将把 §10.4.1 所讨论的线性模型扩展为非线性模型。随后，在 §11.4.2 中，我们将给出这些非线性模型的一个对偶描述——近核方法，以扩展 §10.4.2 所讨论的标准核方法。最后，在 §11.4.3 中，类似于先前在 §10.4.3 中对无限宽度网络所做的工作，我们将看到如何用这一新框架理解有限宽度网络。

11.4.1 非线性模型

回顾 §10.4.1，线性模型由 (10.119) 给出：

$$z_i(x_\delta; \theta) = \sum_{j=0}^{n_f} W_{ij} \phi_j(x_\delta), \quad (11.104)$$

其中模型参数由权重矩阵 $\theta = W_{ij}$ 给出，模型的特征由特征函数 $\phi_j(x)$ 给出；我们再次采用把偏置纳入模型的老式约定，即包含常数特征 $\phi_0(x) \equiv 1$ ，从而偏置向量为 $W_{i0} \equiv b_i$ 。注意，由于这里并非专门讨论神经网络，所以没有神经元指标或层指标。在这个方程中， δ 是样本指标，遍历数据集中的 N_D 个样本 $\delta \in \mathcal{D}$ ； i 是向量指标，遍历模型输出 z_i 的 n_{out} 个向量分量； j 是特征指标，遍历 $(n_f + 1)$ 个不同特征。在此设定中，先在输入样本 x 上计算特征函数 $\phi_j(x)$ ，再由权重矩阵 W_{ij} 决定第 j 个特征对输出第 i 个分量的作用。传统上，特征函数 $\phi_j(x)$ 常被特意设计，使线性模型经过优化或线性回归后能很好地完成目标任务。

为超越这一线性范式，我们稍微形变它，得到一个**非线性模型**：

$$z_i(x_\delta; \theta) = \sum_{j=0}^{n_f} W_{ij} \phi_j(x_\delta) + \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} W_{ij_1} W_{ij_2} \psi_{j_1 j_2}(x_\delta) + \dots \quad (11.105)$$

这里， $\epsilon \ll 1$ 是控制形变大小的小参数；更重要的是，我们引入了另一组带有两个特征指标的特征函数 $\psi_{j_1 j_2}(x)$ ，从而使模型关于权重非线性。按定义， $\psi_{j_1 j_2}(x)$ 在交换特征指标 $j_1 \leftrightarrow j_2$ 下对称；因双重求和会重复计数，故带有因子 $1/2$ 。出于很快就会明了的理

由，我们把 $\psi_{j_1 j_2}(x)$ 的每个分量称为**元特征函数**，因而共有 $(n_f + 1)(n_f + 2)/2$ 个不同的元特征函数。

为熟悉这个模型的特征，考察模型参数发生小变化 $W_{ij} \rightarrow W_{ij} + dW_{ij}$ 时模型输出如何变化：

$$\begin{aligned} & z_i(x_\delta; \theta + d\theta) \\ &= z_i(x_\delta; \theta) + \sum_{j=0}^{n_f} dW_{ij} \left[\phi_j(x_\delta) + \epsilon \sum_{j_1=0}^{n_f} W_{ij_1} \psi_{j_1 j}(x_\delta) \right] + \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} dW_{ij_1} dW_{ij_2} \psi_{j_1 j_2}(x_\delta) + \dots \\ &= z_i(x_\delta; \theta) + \sum_{j=0}^{n_f} dW_{ij} \phi_j^E(x_\delta; \theta) + \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} dW_{ij_1} dW_{ij_2} \psi_{j_1 j_2}(x_\delta) + \dots, \end{aligned} \quad (11.106)$$

最后一行把方括号中的量概括为**有效特征函数**：

$$\phi_{ij}^E(x_\delta; \theta) \equiv \frac{dz_i(x_\delta; \theta)}{dW_{ij}} = \phi_j(x_\delta) + \epsilon \sum_{k=0}^{n_f} W_{ik} \psi_{kj}(x_\delta). \quad (11.107)$$

其用处如下：模型对参数变化的线性响应，仿佛模型有效地拥有一个本身依赖模型参数值的特征函数 $\phi_{ij}^E(x_\delta; \theta)$ 。此外，当模型参数发生小变化 $W_{ik} \rightarrow W_{ik} + dW_{ik}$ 时，有效特征函数的变化为

$$\phi_{ij}^E(x_\delta; \theta + d\theta) = \phi_{ij}^E(x_\delta; \theta) + \epsilon \sum_{k=0}^{n_f} dW_{ik} \psi_{kj}(x_\delta). \quad (11.108)$$

因此，有效特征 $\phi_{ij}^E(x_\delta; \theta)$ 是可学习的，它们像线性模型一样演化；对这些有效特征而言，元特征 $\psi_{kj}(x_\delta)$ 扮演了通常由特征扮演的角色。²²¹ 这样，我们可以把非线性模型视为具有一种层级结构：特征依照 (11.108) 像由线性模型描述那样演化，而模型输出则依照 (11.106) 以更复杂的非线性方式演化。

还可以进一步扩展这一层级结构，例如用一个关于参数三次且包含三指标元元特征函数的项进一步形变非线性模型 (11.105)，从而以类似方式让元特征函数也能够学习。²²² 然而，二次项已经足以给出表征学习的最小模型——正如非零 dNTK 已足以在 MLP 中诱导非平凡表征学习——所以从现在起，我们明确把模型 (11.105) 截断到二次阶，得到一个**二次模型**。²²³

为理解表征学习在这个模型中如何工作，应当在给定训练集 $\mathcal{A}$ 时找出权重 W_{ij}^* 的

²²¹ 元特征 $\psi_{kj}(x_\delta)$ 在有效特征的线性模型中所起的这种作用，解释了我的命名。还要注意，在此设定中，我们假设特征函数 $\phi_j(x)$ 和元特征函数 $\psi_{j_1 j_2}(x)$ 都由模型设计者选取，正如先前为线性模型选取特征函数一样。

²²² 这种形变本质上等价于在任意一般模型函数 $z_i(x_\delta; \theta)$ 的 Taylor 展开中纳入更多项，其中线性模型是基础模型，而非线性模型 (11.105) 是展开给出的第一次改进。

²²³ 在 $1/n$ 展开的领先阶，有限宽度网络不能自洽地由截断的二次模型描述；相反，它们属于一类元特征函数也会演化的三次模型。这是这类有限宽度网络成为非最小表征学习器的一种方式，也是先讨论二次模型、再转向带有动态 dNTK 的有限宽度网络之更复杂分析的主要原因。

最优值. 仿照先前对线性模型所做的工作, 最小化二次模型的 MSE 损失:

$$\begin{aligned}\mathcal{L}_{\mathcal{A}}(\theta) &= \frac{1}{2} \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{i=1}^{n_{\text{out}}} \left[y_{i;\tilde{\alpha}} - z_i(x_{\tilde{\alpha}}; \theta) \right]^2 \\ &= \frac{1}{2} \sum_{\tilde{\alpha} \in \mathcal{A}} \sum_{i=1}^{n_{\text{out}}} \left[y_{i;\tilde{\alpha}} - \sum_{j=0}^{n_f} W_{ij} \phi_j(x_{\tilde{\alpha}}) - \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} W_{ij_1} W_{ij_2} \psi_{j_1 j_2}(x_{\tilde{\alpha}}) \right]^2.\end{aligned}\quad (11.109)$$

使用二次模型 (11.105) 的监督学习并没有专门名称; 但若真要命名, 大家大概都会同意称之为**二次回归**. 然而, 与线性回归不同——其 MSE 损失 (10.120) 关于模型参数是二次的——二次回归的损失关于参数是四次的, 一般不能得到解析解. 尽管如此, 可以对小参数 ϵ 展开, 以微扰方式求解二次回归问题; 就此而言, 回归是近线性的.

近线性二次回归

对损失 $\mathcal{L}_{\mathcal{A}}$ (11.109) 关于模型参数 W_{ij_0} 求导并令其为零, 得到

$$0 = \sum_{\tilde{\alpha}} \phi_{ij_0}^{\text{E}}(x_{\tilde{\alpha}}; \theta^*) [z_i(x_{\tilde{\alpha}}; \theta^*) - y_{i;\tilde{\alpha}}], \quad (11.110)$$

这清楚表明有效特征 (11.107) 给出了模型的线性响应. 接着代入二次模型 (11.104) 和有效特征函数 (11.107), 重新整理后得到

$$\begin{aligned}& \sum_{\tilde{\alpha} \in \mathcal{A}} \left\{ \sum_{j_1=0}^{n_f} W_{ij_1}^* \phi_{j_1}(x_{\tilde{\alpha}}) \phi_{j_0}(x_{\tilde{\alpha}}) + \epsilon \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^* W_{ij_2}^* \left[\phi_{j_1}(x_{\tilde{\alpha}}) \psi_{j_2 j_0}(x_{\tilde{\alpha}}) + \frac{1}{2} \psi_{j_1 j_2}(x_{\tilde{\alpha}}) \phi_{j_0}(x_{\tilde{\alpha}}) \right] \right\} \\ &= \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \left[\phi_{j_0}(x_{\tilde{\alpha}}) + \epsilon \sum_{j_1=0}^{n_f} W_{ij_1}^* \psi_{j_1 j_0}(x_{\tilde{\alpha}}) \right] + O(\epsilon^2).\end{aligned}\quad (11.111)$$

这个表达式包含在线性回归方程 (10.121) 中得到的两项, 以及三个与元特征 $\psi_{j_1 j_2}(x)$ 成正比的附加项. 此外, 由于假设 ϵ 参数性地小, 我们截断了 $O(\epsilon^2)$ 项. 重要的是, 可以清楚看到整个方程是非线性的, 其中两项关于权重为二次. 用物理学语言说, 线性回归的线性方程是自由的且精确可解, 而二次回归的非线性方程是相互作用的. 由于 ϵ 乘在所有与二次回归有关的新项之前, 这些非线性项都很小, 故 (11.111) 呈现弱相互作用动力学. 这意味着可以通过微扰论系统求解这个非线性方程.

为此, 把最优权重矩阵分解为自由线性部分与相互作用非线性部分:

$$W_{ij}^* \equiv W_{ij}^{\text{F}} + W_{ij}^{\text{I}}, \quad (11.112)$$

其思路是: 自由部分 W_{ij}^{F} 求解自由线性回归方程 (10.121); 把 W_{ij}^{F} 的解代回后, 相互作用部分 W_{ij}^{I} 求解剩余的线性化方程. 由于在 $\epsilon \rightarrow 0$ 极限下, 二次回归问题 (11.111) 变成线性回归问题 (10.121), 自然预期最优权重的相互作用部分与小参数成正比, 即 $W_{ij}^{\text{I}} = O(\epsilon)$.

现在简要回顾 §10.4.1 中线性回归的**直接优化**解. 定义 (10.122) 中的 $(n_f + 1) \times (n_f + 1)$ 对称矩阵

$$M_{j_1 j_2} \equiv \sum_{\tilde{\alpha} \in \mathcal{A}} \phi_{j_1}(x_{\tilde{\alpha}}) \phi_{j_2}(x_{\tilde{\alpha}}), \quad (11.113)$$

二次回归问题 (11.111) 的线性部分可写为

$$\sum_{j_1=0}^{n_f} W_{ij_1}^F M_{j_1 j_0} = \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \phi_{j_0}(x_{\tilde{\alpha}}), \quad (11.114)$$

乘以逆矩阵 $(M^{-1})_{j_0 j}$ 即可求解:

$$W_{ij}^F = \sum_{j_0=0}^{n_f} \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \phi_{j_0}(x_{\tilde{\alpha}}) (M^{-1})_{j_0 j}. \quad (11.115)$$

回顾一下, 如果处在特征数多于训练样本数的过参数化区间 $(n_f + 1) > N_{\mathcal{A}}$, 逆矩阵 $(M^{-1})_{j_0 j}$ 并不唯一存在; 但可以使用正则化技巧 (10.124) 选出一个特定的逆. 下文假设我们处于这一过参数化区间, 并已经如此选定逆矩阵.

接着, 把分解 (11.112) 代入方程 (11.111), 收集 ϵ 阶项并记住 $W_{ij}^I = O(\epsilon)$, 得到线性化的相互作用动力学:

$$\begin{aligned} \sum_{j_1=0}^{n_f} W_{ij_1}^I M_{j_1 j_0} = & \epsilon \sum_{j_1=0}^{n_f} W_{ij_1}^F \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \psi_{j_1 j_0}(x_{\tilde{\alpha}}) - \epsilon \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^F W_{ij_2}^F \sum_{\tilde{\alpha} \in \mathcal{A}} \phi_{j_1}(x_{\tilde{\alpha}}) \psi_{j_2 j_0}(x_{\tilde{\alpha}}) \\ & - \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^F W_{ij_2}^F \sum_{\tilde{\alpha} \in \mathcal{A}} \phi_{j_0}(x_{\tilde{\alpha}}) \psi_{j_1 j_2}(x_{\tilde{\alpha}}) + O(\epsilon^2). \end{aligned} \quad (11.116)$$

右端前两项实际上彼此抵消, 因为自由解满足

$$\sum_{j=0}^{n_f} W_{ij}^F \phi_j(x_{\tilde{\alpha}}) = y_{i;\tilde{\alpha}}, \quad (11.117)$$

也就是说, 对过参数化模型, 优化后模型的线性部分能够正确预测训练集中的所有样本.²²⁴ 完成抵消后, 乘以逆矩阵 $(M^{-1})_{j_0 j}$, 得到一个解:

$$W_{ij}^I = -\frac{\epsilon}{2} \sum_{j_1, j_2, j_3=0}^{n_f} W_{ij_1}^F W_{ij_2}^F \sum_{\tilde{\alpha} \in \mathcal{A}} [\psi_{j_1 j_2}(x_{\tilde{\alpha}}) \phi_{j_3}(x_{\tilde{\alpha}})] (M^{-1})_{j_3 j} + O(\epsilon^2). \quad (11.118)$$

具体而言, 自由解 (11.115) 与相互作用解 (11.118) 一起, 在 ϵ 阶求解了非线性优化问题 (11.111).²²⁵

最后, 得到解后便可丢弃训练数据, 只存储最优参数 $W_{ij}^* = W_{ij}^F + W_{ij}^I$, 并对新的

²²⁴这一点在 §10.4.2 中有详细说明. 对欠参数化模型, 解仍可分析, 但细节会不同. 这里聚焦过参数化模型, 是因为 (i) 深度学习模型通常是过参数化的, 并且 (ii) 我们猜测, 本模型展现的这种表征学习在该区间最为有用. 结语 ϵ 将对此作更深入的阐述.

²²⁵实际进行近线性二次回归时, 最合理的做法大概是先求出最优线性参数 W_{ij}^F , 再把它们代回 (11.118), 求出额外的非线性参数 W_{ij}^I .

测试输入 $x_{\hat{\beta}}$ 作预测:

$$\begin{aligned}
 z_i(x_{\hat{\beta}}; \theta^*) &= \sum_{j=0}^{n_f} W_{ij}^* \phi_j(x_{\hat{\beta}}) + \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^* W_{ij_2}^* \psi_{j_1 j_2}(x_{\hat{\beta}}) \\
 &= \sum_{j=0}^{n_f} W_{ij}^F \phi_j(x_{\hat{\beta}}) + \sum_{j=0}^{n_f} W_{ij}^I \phi_j(x_{\hat{\beta}}) + \frac{\epsilon}{2} \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^F W_{ij_2}^F \psi_{j_1 j_2}(x_{\hat{\beta}}) + O(\epsilon^2) \\
 &= \frac{1}{2} \sum_{j=0}^{n_f} W_{ij}^* [\phi_j(x_{\hat{\beta}}) + \phi_{ij}^E(x_{\hat{\beta}}; \theta^*)] + O(\epsilon^2).
 \end{aligned} \tag{11.119}$$

这里给出了理解最优输出的两种不同方式. 在前两行中, 这就是用固定特征 $\phi_j(x_{\hat{\beta}})$ 和固定元特征 $\psi_{j_1 j_2}(x_{\hat{\beta}})$ 表示的二次模型 (11.105) 的预测; 这种表示使非线性显而易见. 重新组合各项并使用定义 (11.107) 后, 最后一行改把模型预测写成线性模型的形式; 在这种解释中, 特征是固定未学习特征与已学习有效特征的平均. 从这一视角看, 表征学习显而易见: 有效特征 $\phi_{ij}^E(x_{\hat{\beta}}; \theta^*)$ 通过最优参数 $W_{ij}^* = W_{ij}^*(x_{\bar{\alpha}}, y_{\bar{\alpha}})$ 依赖于训练数据.

总之, 非线性二次模型 (11.105) 是表征学习的最小模型. 很快将看到, 它捕捉了非零但固定的 dNTK 所引起的特征演化机制.

旁论: 线性回归与二次回归的模型比较

在转向二次模型的对偶样本空间描述之前, 先简要比较线性回归与二次回归. 具体而言, 考察这两类模型的模型复杂度.²²⁶

对线性回归和二次回归, 模型参数数目都等于组合权重矩阵 W_{ij} 的元素数:

$$P \equiv n_{\text{out}} \times (n_f + 1). \tag{11.120}$$

由于在固定且相等的参数数目下, 两个模型都完全记忆同一个训练集, 显然不能朴素地使用奥卡姆剃刀启发法 (§6.2.2) 作模型比较. 这使我们的模型比较略显微妙.

一方面, 在某种意义上二次模型更复杂, 因为它对每个参数计算了多得多的输入函数. 具体而言, 按每个参数计, 二次模型需要指定的底层函数远多于线性模型, 即需要

$$(n_f + 1) + \left[\frac{1}{2} (n_f + 1)(n_f + 2) \right] = O(P^2) \tag{11.121}$$

个数来指定 $\phi_j(x)$ 和 $\psi_{j_1 j_2}(x)$, 而指定 $\phi_j(x)$ 只需

$$(n_f + 1) = O(P) \tag{11.122}$$

个数. 特别地, 模型函数的计数由元特征函数 $\psi_{j_1 j_2}(x)$ 主导. 因此, 这类复杂度并未真正由模型参数数目 P 捕捉; 它通过添加元特征函数 $\psi_{j_1 j_2}(x)$, 体现在模型结构中.

另一方面, 可以把这些附加元特征函数理解为: 依据一个显式的表征学习归纳偏置来约束二次模型.²²⁷ 具体而言, 这一附加结构通过加入 $O(\epsilon)$ 调谐 W_{ij}^I 改变线性模型

²²⁶ 关于模型复杂度的进一步讨论, 尤其是直接针对过参数化深度学习模型的讨论, 参见结语 ϵ .

²²⁷ 类似地, 我们可能会朴素地认为, 在损失中加入 $\sum_{\mu=1}^P a_{\mu} \theta_{\mu}^2$ 这样的正则化项, 会因额外结构而使模型更加复杂, 尽管正则化是众所周知的过拟合补救方法. 更好的理解大概是把这一正则化项看作一种归纳偏置, 它约束优化后模型参数的模平方.

解 (11.115); 这些调谐受学习开始前定义的 $O(P^2)$ 个元特征约束. 若这些元特征函数确实有用, 便可预期二次模型过拟合更少、泛化更好.²²⁸ (事实上, 引入它们的目的正是如此.)

后一点值得再讨论几句. 过拟合的典型标志之一是参数经过极端**精细调谐**; 这种调谐在某种意义上是不自然的, 它可能源于过参数化模型提供的极端灵活性, 使模型能够精确穿过所有训练点, 却严重损害测试预测.²²⁹ 在参数模上加入正则化项——即刚才脚注 227 讨论的项——能够抵抗这种调谐: 优化问题中的附加约束把参数模推向零, 从而有效地促进参数稀疏. 在这里, 由于最优权重的非线性贡献 W_{ij}^I 被固定为小量 $O(\epsilon)$, 它加入了约束; 若这些约束有用, 就能抵抗线性解 W_{ij}^F 中可能出现的精细调谐, 并带来更好的泛化.

11.4.2 近核方法

现在, 我们对非线性模型相较于线性模型的潜在优势已经有了更多参数空间直觉; 接下来建立二次回归的对偶样本空间描述, 其中会自然出现 dNTK 的二次模型对应物.

从预测公式 (11.119) 第二行出发, 代入自由解 (11.115) 与相互作用解 (11.118), 得到

$$\begin{aligned} z_i(x_{\beta}; \theta^*) &= \sum_{\tilde{\alpha} \in \mathcal{A}} y_{i;\tilde{\alpha}} \left[\sum_{j_1, j_2=0}^{n_f} \phi_{j_1}(x_{\tilde{\alpha}}) (M^{-1})_{j_1 j_2} \phi_{j_2}(x_{\beta}) \right] \\ &+ \frac{\epsilon}{2} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2} \sum_{j_1, j_2, j_3, j_4=0}^{n_f} \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \\ &\times \left[\psi_{j_3 j_4}(x_{\beta}) - \sum_{\tilde{\alpha} \in \mathcal{A}} \psi_{j_3 j_4}(x_{\tilde{\alpha}}) \sum_{j_5, j_6=0}^{n_f} \phi_{j_5}(x_{\tilde{\alpha}}) (M^{-1})_{j_5 j_6} \phi_{j_6}(x_{\beta}) \right] + O(\epsilon^2). \end{aligned} \quad (11.124)$$

为简化此式, 回忆讨论核方法时推导的公式 (10.131):

$$\sum_{j_1, j_2=0}^{n_f} \phi_{j_1}(x_{\tilde{\alpha}}) (M^{-1})_{j_1 j_2} \phi_{j_2}(x_{\beta}) = k_{\beta \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}}, \quad (11.125)$$

²²⁸有趣的是, 对二次模型, 有效特征函数 (11.107) 的数目实际上与模型参数数目相同: $n_{\text{out}} \times (n_f + 1) = P$. 元特征函数只能通过这些有效特征进入模型预测, 参见 (11.119); 这进一步强调, 尽管存在附加模型结构, 实际并没有 $O(P^2)$ 个可用于拟合训练数据的独立自由度.

²²⁹这一点通常用线性回归的多项式特征函数基来说明, 有时称为多项式回归. 考虑标量输入 x 上标量函数 $f(x)$ 的线性模型:

$$z(x_{\delta}; \theta) = \sum_{j=0}^{n_f} w_j \phi_j(x_{\delta}) \equiv w_0 + w_1 x_{\delta} + w_2 x_{\delta}^2 + \cdots + w_{n_f} x_{\delta}^{n_f}. \quad (11.123)$$

只要数据中有任何噪声, 在模型过参数化 $n_f + 1 > N_A$ 时, 这个一维函数的图像就会急剧转折约 n_f 次, 以穿过 N_A 个训练点. (当目标函数是带噪声的简单线性函数时尤其形象, 即 $f(x) = ax + b + \epsilon$, 其中 ϵ 是方差很小 $\sigma_{\epsilon}^2 \ll 1$ 的零均值高斯噪声.) 为了实现这些转折, 由 (11.115) 算出的最优系数 w_j^* 必须精细调谐到许多有效数字. 模型参数中的这类精细调谐问题表明模型不自然或有误; 事实上, 这个问题在高能理论物理学中的对应概念称为自然性 (非技术性讨论参见例如 [68]).

其中的核在 (10.127) 中定义为

$$k_{\delta_1 \delta_2} \equiv k(x_{\delta_1}, x_{\delta_2}) \equiv \sum_{j=0}^{n_f} \phi_j(x_{\delta_1}) \phi_j(x_{\delta_2}), \quad (11.126)$$

它度量两个输入 $x_{i;\delta_1}$ 与 $x_{i;\delta_2}$ 在特征空间中的相似性. 将 (11.125) 代回二次回归预测公式 (11.124), 得到

$$\begin{aligned} z_i(x_{\beta}; \theta^*) &= \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{\beta \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i;\tilde{\alpha}_2} \\ &+ \frac{\epsilon}{2} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} y_{i;\tilde{\alpha}_1} y_{i;\tilde{\alpha}_2} \sum_{j_1, j_2, j_3, j_4=0}^{n_f} \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \\ &\times \left[\psi_{j_3 j_4}(x_{\beta}) - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{\beta \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \psi_{j_3 j_4}(x_{\tilde{\alpha}_2}) \right] + O(\epsilon^2), \end{aligned} \quad (11.127)$$

这个形式已经稍为简洁.

要进一步化简, 需要理解如下形式的对象:

$$\sum_{j_1, j_2, j_3, j_4=0}^{n_f} \epsilon \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \psi_{j_3 j_4}(x_{\delta}). \quad (11.128)$$

仿照推导核方法公式 (11.125) 时在 (10.130) 中所做的步骤, 用两个训练集核作用于这个对象:

$$\begin{aligned} &\sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \left[\sum_{j_1, j_2, j_3, j_4=0}^{n_f} \epsilon \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \psi_{j_3 j_4}(x_{\delta}) \right] \tilde{k}_{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{k}_{\tilde{\alpha}_2 \tilde{\alpha}_4} \\ &= \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \sum_{j_1, \dots, j_6=0}^{n_f} \epsilon \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \\ &\quad \times \psi_{j_3 j_4}(x_{\delta}) \phi_{j_5}(x_{\tilde{\alpha}_3}) \phi_{j_5}(x_{\tilde{\alpha}_3}) \phi_{j_6}(x_{\tilde{\alpha}_2}) \phi_{j_6}(x_{\tilde{\alpha}_4}) \\ &= \sum_{j_1, \dots, j_6=0}^{n_f} \epsilon M_{j_1 j_5} (M^{-1})_{j_1 j_3} M_{j_2 j_6} (M^{-1})_{j_2 j_4} \psi_{j_3 j_4}(x_{\delta}) \phi_{j_5}(x_{\tilde{\alpha}_3}) \phi_{j_6}(x_{\tilde{\alpha}_4}) \\ &= \sum_{j_1, j_2=0}^{n_f} \epsilon \psi_{j_1 j_2}(x_{\delta}) \phi_{j_1}(x_{\tilde{\alpha}_3}) \phi_{j_2}(x_{\tilde{\alpha}_4}). \end{aligned} \quad (11.129)$$

第二行用核的定义 (11.126) 将两个核换成特征函数; 第三行用对称矩阵 $M_{j_1 j_2}$ 的定义 (11.113) 替换两对特征函数; 最后一行则直接将这些矩阵与其逆矩阵约去.

最后一个表达式提示我们定义如下重要对象:

$$\mu_{\delta_0 \delta_1 \delta_2} \equiv \sum_{j_1, j_2=0}^{n_f} \epsilon \psi_{j_1 j_2}(x_{\delta_0}) \phi_{j_1}(x_{\delta_1}) \phi_{j_2}(x_{\delta_2}), \quad (11.130)$$

称为**元核**.²³⁰ 与核方法的核 (11.126) 类似, 元核是与参数无关的张量, 在交换最后两个样本指标 $\delta_1 \leftrightarrow \delta_2$ 下对称, 并完全由定义模型的固定特征函数与元特征函数给出. 对 (11.130) 的一种理解是: 固定某个输入 x_{δ_0} 后, 元核计算另外两个输入 x_{δ_1} 与 x_{δ_2} 之间一种不同的特征空间内积. 还要注意, 由于元核的定义 (11.130) 含有小参数 ϵ , 也应把 $\mu_{\delta_0\delta_1\delta_2}$ 视为参数意义下的小量.

借助这一定义, 关系 (11.129) 可简写为

$$\begin{aligned} & \sum_{j_1, j_2, j_3, j_4=0}^{n_f} \epsilon \phi_{j_1}(x_{\tilde{\alpha}_1}) (M^{-1})_{j_1 j_3} \phi_{j_2}(x_{\tilde{\alpha}_2}) (M^{-1})_{j_2 j_4} \psi_{j_3 j_4}(x_{\delta}) \\ &= \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \mu_{\delta \tilde{\alpha}_3 \tilde{\alpha}_4} \tilde{k}^{\tilde{\alpha}_3 \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_4 \tilde{\alpha}_2}. \end{aligned} \quad (11.131)$$

最后代回 (11.127), 得到

$$\begin{aligned} z_i(x_{\tilde{\beta}}; \theta^*) &= \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{\tilde{\beta} \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2} \\ &+ \frac{1}{2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \left[\mu_{\tilde{\beta} \tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6 \in \mathcal{A}} k_{\tilde{\beta} \tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \mu_{\tilde{\alpha}_6 \tilde{\alpha}_1 \tilde{\alpha}_2} \right] \left(\tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_3} y_{i; \tilde{\alpha}_3} \right) \left(\tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_4} y_{i; \tilde{\alpha}_4} \right). \end{aligned} \quad (11.132)$$

这样计算二次模型预测时, 我们称其为近核机或**近核方法**.²³¹

²³⁰这个对象的另一个名称是核的微分, 相应可记为 $\mu_{\delta_0\delta_1\delta_2} \rightarrow dk_{\delta_0\delta_1\delta_2}$. 这一名称—符号组合突出了我们即将建立的有限宽度网络联系, 但在构建更广泛的表征学习模型时或许不够普适.

²³¹不同于核方法, 这个解依赖学习算法的细节. 例如, 若不用直接优化 (11.110), 而用梯度下降优化二次回归损失 (11.109), 则在零初始化 $W_{ij} = 0$ 下, 近核预测公式改为

$$\begin{aligned} z_i(x_{\tilde{\beta}}; \theta^*) &= \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{\tilde{\beta} \tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_2} y_{i; \tilde{\alpha}_2} \\ &+ \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \left[\mu_{\tilde{\alpha}_1 \tilde{\beta} \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6 \in \mathcal{A}} k_{\tilde{\beta} \tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \mu_{\tilde{\alpha}_1 \tilde{\alpha}_6 \tilde{\alpha}_2} \right] Z_A^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} y_{i; \tilde{\alpha}_3} y_{i; \tilde{\alpha}_4} \\ &+ \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \left[\mu_{\tilde{\beta} \tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6 \in \mathcal{A}} k_{\tilde{\beta} \tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \mu_{\tilde{\alpha}_6 \tilde{\alpha}_1 \tilde{\alpha}_2} \right] Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} y_{i; \tilde{\alpha}_3} y_{i; \tilde{\alpha}_4} \end{aligned} \quad (11.133)$$

其中算法投影算子为

$$Z_A^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_4} - \sum_{\tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_5} X_{\Pi}^{\tilde{\alpha}_1 \tilde{\alpha}_5 \tilde{\alpha}_3 \tilde{\alpha}_4}, \quad (11.134)$$

$$Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_4} - \sum_{\tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_5} X_{\Pi}^{\tilde{\alpha}_1 \tilde{\alpha}_5 \tilde{\alpha}_3 \tilde{\alpha}_4} + \frac{\eta}{2} X_{\Pi}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}, \quad (11.135)$$

张量 $X_{\Pi}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ 隐式满足

$$\sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} X_{\Pi}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \left(\tilde{k}^{\tilde{\alpha}_3 \tilde{\alpha}_5} \delta_{\tilde{\alpha}_4 \tilde{\alpha}_6} + \delta_{\tilde{\alpha}_3 \tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_4 \tilde{\alpha}_6} - \eta \tilde{k}^{\tilde{\alpha}_3 \tilde{\alpha}_5} \tilde{k}^{\tilde{\alpha}_4 \tilde{\alpha}_6} \right) = \delta_{\tilde{\alpha}_5}^{\tilde{\alpha}_1} \delta_{\tilde{\alpha}_6}^{\tilde{\alpha}_2}, \quad (11.136)$$

η 为全局学习率. 学完 §8.2.2 后, 这个梯度下降解的来源应当很清楚. 对非线性过参数化模型而言, 这种算法依赖性并不意外, 也是有限宽度网络的重要特征. 不过, 本节余下部分仍分析直接优化公式 (11.132), 其中 $Z_A^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} = 0$, $Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} = \tilde{k}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{k}^{\tilde{\alpha}_2 \tilde{\alpha}_4} / 2$.

与线性模型类似, 非线性二次模型的预测解仍有两种理解: 一方面, 用最优参数 (11.115)、(11.118) 作出预测 (11.119); 另一方面, 用 (11.132) 作出不显含特征、元特征和模型参数的近核预测. 也就是说, 我们以样本空间量 $k_{\delta\tilde{\alpha}}$ 、 $\mu_{\delta_0\tilde{\alpha}_1\tilde{\alpha}_2}$ 、 $y_{i;\tilde{\alpha}}$ 换掉了特征空间量 $\phi_j(x)$ 、 $\psi_{j_1j_2}(x)$ 、 W_{ij}^* . 这是因为预测公式中的所有特征指标都已缩并, 结果只会出现上述核组合.²³² 微观特征空间描述与宏观样本空间描述之间的这种对偶, 是 §0.1 所述有效理论方法的又一次体现; 在 §∞ 讨论有限宽度网络动力学后, 我们将在结语 ε 中再次评论这种对偶.

最后, 近核预测同样通过与已见样例直接比较来计算. 它既有与 $y_{i;\tilde{\alpha}_2}$ 成正比的线性部分, 又有跨不同训练样例、与 $y_{i;\tilde{\alpha}_1}y_{i;\tilde{\alpha}_2}$ 成正比的新二次部分. 因此, 近核方法也是需要记住整个训练集的基于记忆的方法.

这里所指的正是预测公式 (11.119) 中的缩并结构.

已训练核预测

尽管这些近核方法极其接近核方法, 参数之间的相互作用仍使二者存在真正的定性差异. 在 §11.4.1 描述的特征空间图景中, 这一差异表现为有效特征 $\phi_{ij}^E(x, \theta)$ 的非平凡特征学习, 如二次模型预测公式 (11.119) 最后一行所示. 为从对偶样本空间图景理解这一点, 类似地定义**有效核**

$$k_{ii;\delta_1\delta_2}^E(\theta) \equiv \sum_{j=0}^{n_f} \phi_{ij}^E(x_{\delta_1}; \theta) \phi_{ij}^E(x_{\delta_2}; \theta), \quad (11.137)$$

它利用有效特征 (11.107) 度量两个输入 x_{δ_1} 与 x_{δ_2} 之间依赖参数的相似性. 有趣的是, 模型实际上为每个输出分量 i 给出不同的有效核.²³³ 在训练结束时计算有效核:

$$\begin{aligned} k_{ii;\delta_1\delta_2}^E(\theta^*) &\equiv \sum_{j=0}^{n_f} \phi_{ij}^E(x_{\delta_1}; \theta^*) \phi_{ij}^E(x_{\delta_2}; \theta^*) \\ &= \sum_{j=0}^{n_f} \phi_j(x_{\delta_1}) \phi_j(x_{\delta_2}) + \sum_{j_1, j_2=0}^{n_f} W_{ij_1}^F [\psi_{j_1j_2}(x_{\delta_1}) \phi_{j_2}(x_{\delta_2}) + \psi_{j_1j_2}(x_{\delta_2}) \phi_{j_2}(x_{\delta_1})] + O(\epsilon^2) \\ &= k_{\delta_1\delta_2} + \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} (\mu_{\delta_1\delta_2\tilde{\alpha}_1} + \mu_{\delta_2\delta_1\tilde{\alpha}_1}) \tilde{k}^{\tilde{\alpha}_1\tilde{\alpha}_2} y_{i;\tilde{\alpha}_2} + O(\epsilon^2). \end{aligned} \quad (11.138)$$

最后一行代入了自由解 (11.115), 并暗中使用关系

$$\phi_{j_0}(x_{\tilde{\alpha}}) (M^{-1})_{j_0j_1} \psi_{j_1j_2}(x_{\delta_1}) \phi_{j_2}(x_{\delta_2}) = \sum_{\tilde{\alpha}_1 \in \mathcal{A}} \mu_{\delta_1\delta_2\tilde{\alpha}_1} \tilde{k}^{\tilde{\alpha}_1\tilde{\alpha}}, \quad (11.139)$$

²³²正如 §10 脚注 203 所述, 有时指定并求值元核 $\mu_{\delta_0\delta_1\delta_2}$ 比指定并求值元特征函数 $\psi_{j_1j_2}(x)$ 简单得多. 或许存在不依赖神经网络底层描述的其他启发式构造. 确定一般三输入函数 $\mu(x_{\delta_0}, x_{\delta_1}, x_{\delta_2}) \equiv \mu_{\delta_0\delta_1\delta_2}$ 成为元核的充要条件, 将很有意义.

²³³这里, 有效核下标中用两个 i 表示输出分量只是约定; 稍后在稍不极简的模型 (11.146) 中会需要带非对角分量的版本.

其推导类似于 (10.130) 和 (11.129) 中的操作.²³⁴ 式 (11.138) 表明, 有效核相对原核发生偏移, 并包含与元核和真实训练输出 $y_{i;\tilde{\alpha}}$ 成正比的贡献; 其输出分量依赖性正由此产生.

最后再定义一个核:

$$k_{ii;\delta_1\delta_2}^\# \equiv \frac{1}{2} [k_{\delta_1\delta_2} + k_{ii;\delta_1\delta_2}^E(\theta^*)] . \quad (11.140)$$

这个**已训练核**平均了线性模型中简单核方法的核与学得近核方法有效核. 按通常方式定义训练集上已训练核子矩阵的逆:

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{k}_{ii}^{\tilde{\alpha}_1\tilde{\alpha}_2} \tilde{k}_{ii;\tilde{\alpha}_2\tilde{\alpha}_3}^\# = \delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1} , \quad (11.141)$$

于是近核预测公式 (11.132) 可压缩为

$$z_i(x_{\tilde{\beta}}; \theta^*) = \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} k_{ii;\tilde{\beta}\tilde{\alpha}_1}^\# \tilde{k}_{ii}^{\tilde{\alpha}_1\tilde{\alpha}_2} y_{i;\tilde{\alpha}_2} + O(\epsilon^2) , \quad (11.142)$$

它具有核预测的形式, 同时已训练核纳入了非平凡特征演化的益处.²³⁵ 表征学习正是以这种方式体现在近核方法中.

最后请注意, 在我们的表征学习最小模型中, n_{out} 个输出分量之间没有接线或混合: 尽管预测 $z_i(x_{\tilde{\beta}}; \theta^*)$ 是真实输出 $y_{i;\tilde{\alpha}}$ 的二次函数——从 (11.132) 最容易看出——它仍只涉及第 i 个分量. 从**已训练核预测** (11.142) 看, 每个输出分量 i 都有不同的已训练核, 但第 i 个预测绝不依赖 $i' \neq i$ 的其他真实输出分量 $y_{i';\tilde{\alpha}}$.

不过, 这种没有接线的性质是有意设计的; 该表征学习模型本来就旨在保持最小. 为使输出分量混合, 必须稍微推广二次模型. 下一节说明如何用近核方法框架描述有限宽度网络时, 我们就会这样做.

11.4.3 作为非线性模型的有限宽度网络

尽管本节至今的讨论与深度学习框架略显脱节, 其中许多内容应当仍很熟悉. 例如, 训练结束时的有效核公式 (11.138) 似乎与 NTK 更新 (11.10) 有关: 只需把元核 $\mu_{\delta_0\delta_1\delta_2}$ 与 $\text{dNTK } \widehat{\text{dH}}_{i_0i_1i_2;\delta_0\delta_1\delta_2}$ 对应起来, 并沿用 §10.4.3 中核方法的核与 NTK 之间的对应. 下面精确建立有限宽度网络与非线性模型的联系.

首先, 为神经网络定义有效特征函数 $\phi_{ij}^E(x_\delta; \theta)$ (11.107) 的对应物:

$$\phi_{i,\mu}^E(x_\delta; \theta) \equiv \frac{dz_{i;\delta}^{(L)}}{d\theta_\mu} . \quad (11.143)$$

在无限宽度网络的线性模型描述中, 模型输出的导数为常数, 这些特征在训练期间完全固定. 相反, 对二次模型和有限宽度网络, 导数 (11.143) 并非常数, 因而有效特征会随

²³⁴若改用梯度下降优化二次回归损失 (11.109), 训练结束时的有效核 $k_{ii;\delta_1\delta_2}^E(\theta^*)$ 将不同于直接优化所得的 (11.138); 参见脚注 231.

²³⁵要验证此式, 使用已训练核的定义 (11.140), 再利用 Schwinger–Dyson 方程 (4.55) 对有效核展开并计算矩阵逆. 结果应与近核预测公式 (11.132) 一致.

模型参数移动而演化. 对函数逼近器本身, 参数发生小变化 $\theta \rightarrow \theta + d\theta$ 后, 网络输出演化为

$$\begin{aligned} z_{i;\delta}^{(L)}(\theta + d\theta) &= z_{i;\delta}^{(L)}(\theta) + \sum_{\mu=1}^P \frac{dz_{i;\delta}^{(L)}}{d\theta_\mu} d\theta_\mu + \frac{1}{2} \sum_{\mu,\nu=1}^P \frac{d^2 z_{i;\delta}^{(L)}}{d\theta_\mu d\theta_\nu} d\theta_\mu d\theta_\nu + \dots, \\ &= z_{i;\delta}^{(L)}(\theta) + \sum_{\mu=1}^P \phi_{i,\mu}^E(x_\delta; \theta) d\theta_\mu + \frac{\epsilon}{2} \sum_{\mu,\nu=1}^P \hat{\psi}_{i,\mu\nu}(x_\delta) d\theta_\mu d\theta_\nu + \dots, \end{aligned} \quad (11.144)$$

其中还定义了神经网络的元特征函数对应物:

$$\epsilon \hat{\psi}_{i,\mu\nu}(x_\delta) \equiv \frac{d^2 z_{i;\delta}^{(L)}}{d\theta_\mu d\theta_\nu}. \quad (11.145)$$

这里截断 (11.144) 中的 “...”, 使输出更新恰为参数小变化的二次函数. 截断后, 有限宽度网络的更新 (11.144) 与二次模型迈出小步后的更新 (11.106) 相同.²³⁶

在线性模型描述的无限宽度网络中, 元特征函数 (11.145) 恒为零, 因而不影响动力学. 对作二次截断的有限宽度网络, 元特征 (11.145) 在参数意义下虽小却不再为零; 它们在初始化时随机抽样, 训练期间保持固定, 故带有帽号. 因此在二次阶称 $\hat{\psi}_{i,\mu\nu}(x)$ 为 **随机元特征**, 正如无限宽度网络的特征函数称为随机特征.

建立特征空间联系后, 再建立对偶样本空间联系. 与有效特征 (11.143) 相伴的有效核 $k_{i_1 i_2; \delta_1 \delta_2}^E(\theta)$ (11.137) 定义为

$$k_{i_1 i_2; \delta_1 \delta_2}^E(\theta) = \sum_{\mu,\nu} \lambda_{\mu\nu} \phi_{i_1,\mu}^E(x_{\delta_1}; \theta) \phi_{i_2,\nu}^E(x_{\delta_2}; \theta) = \sum_{\mu,\nu} \lambda_{\mu\nu} \frac{dz_{i_1;\delta_1}^{(L)}}{d\theta_\mu} \frac{dz_{i_2;\delta_2}^{(L)}}{d\theta_\nu} \equiv H_{i_1 i_2; \delta_1 \delta_2}^{(L)}(\theta). \quad (11.146)$$

这里采用更一般的核定义 (10.136) 纳入学习率张量. 由于有效特征 (11.143) 依赖参数, 最后一个等号采用最一般的 NTK 定义 (7.17), 并以参数 θ 显示其参数依赖. 特别地, 在初始化 $\theta = \theta(t=0)$ 处, 用随机特征

$$\hat{\phi}_{i,\mu}(x_\delta) \equiv \phi_{i,\mu}^E(x_\delta; \theta(t=0)) = \left. \frac{dz_{i;\delta}^{(L)}}{d\theta_\mu} \right|_{\theta=\theta(t=0)}, \quad (11.147)$$

计算有效核, 便得到通常的第 L 层初始化随机 NTK (8.5):

$$\begin{aligned} \hat{k}_{i_1 i_2; \delta_1 \delta_2} &\equiv k_{i_1 i_2; \delta_1 \delta_2}^E(\theta(t=0)) = \sum_{\mu,\nu} \lambda_{\mu\nu} \hat{\phi}_{i_1,\mu}(x_{\delta_1}) \hat{\phi}_{i_2,\nu}(x_{\delta_2}) \\ &= \sum_{\mu,\nu} \lambda_{\mu\nu} \left(\frac{dz_{i_1;\delta_1}^{(L)}}{d\theta_\mu} \frac{dz_{i_2;\delta_2}^{(L)}}{d\theta_\nu} \right) \Big|_{\theta=\theta(t=0)} \equiv \hat{H}_{i_1 i_2; \delta_1 \delta_2}^{(L)}. \end{aligned} \quad (11.148)$$

²³⁶ 根据二次模型定义 (11.105), 这一对应中包含了小参数 ϵ . 对 MLP, 该参数由架构自动设定, 等于有效理论截断——网络的深宽比: $\epsilon \equiv L/n$. 但有限宽度网络还有其他同为 $\epsilon \equiv L/n$ 阶的项, 必须一并纳入才能得到自洽描述, 下文很快说明.

对无限宽度网络, 该 NTK 在训练期间不演化, 并由初始化随机特征 (10.138) 构成. 相反, 如 §11.1 所见, 有限宽度网络的有效核 (11.146) 在训练期间确实演化, 正如二次模型的有效核 (11.137).

最后, 类似于二次模型的元核 (11.130), 也可构造有限宽度网络的元核. 它由随机特征 (11.147) 与随机元特征 (11.145) 组成:

$$\begin{aligned}\widehat{\mu}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2} &\equiv \sum_{\substack{\mu_1, \nu_1, \\ \mu_2, \nu_2}} \epsilon \lambda_{\mu_1 \nu_1} \lambda_{\mu_2 \nu_2} \widehat{\psi}_{i_0, \mu_1 \mu_2}(x_{\delta_0}) \widehat{\phi}_{i_1, \nu_1}(x_{\delta_1}) \widehat{\phi}_{i_2, \nu_2}(x_{\delta_2}) \\ &= \sum_{\substack{\mu_1, \nu_1, \\ \mu_2, \nu_2}} \lambda_{\mu_1 \nu_1} \lambda_{\mu_2 \nu_2} \left(\frac{d^2 z_{i_0; \delta_0}^{(L)}}{d\theta_{\mu_1} d\theta_{\mu_2}} \frac{dz_{i_1; \delta_1}^{(L)}}{d\theta_{\nu_1}} \frac{dz_{i_2; \delta_2}^{(L)}}{d\theta_{\nu_2}} \right) \Big|_{\theta=\theta(t=0)} \equiv \widehat{dH}_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(L)},\end{aligned}\quad (11.149)$$

这里通过纳入学习率张量, 略微推广了元核定义 (11.130).²³⁷ 因而, 随机元核 (11.149) 已与第 L 层随机 dNTK (11.8) 对应起来.

建立这些联系后, 最小二次模型与有限宽度神经网络有三个显著差异.

第一, 由随机特征与随机元特征的定义 (11.147)、(11.145) 可知, 这些函数是随机的而非人工设计的: 它们由网络架构细节决定, 并依赖初始化时随机抽取的参数值. 更一般地, 可把形如 (11.105)、具有随机函数 $\widehat{\phi}_j(x)$ 与 $\widehat{\psi}_{j_1 j_2}(x)$ 的二次模型称为**随机元特征模型**; 它推广了 §10.4.3 中结合无限宽度网络和线性模型讨论的随机特征模型.

第二, 如 §11.4.2 末尾所述, 二次模型 (11.105) 对测试输入作近核预测 (11.132) 时, 不会把训练集真实输出的不同分量接线起来. 相反, 稍后将在 §∞.2.3 证明有限宽度网络预测具有这种接线性质. 二次模型的缺陷其实是为了消除表征学习最小模型中的额外复杂性而有意设计的. 为纳入接线, 可将二次模型稍微推广为

$$z_i(x_\delta; \theta) = \sum_{\mu=1}^P \theta_\mu \widehat{\phi}_{i, \mu}(x_\delta) + \frac{\epsilon}{2} \sum_{\mu, \nu=1}^P \theta_\mu \theta_\nu \widehat{\psi}_{i, \mu \nu}(x_\delta). \quad (11.150)$$

这个稍不极简的模型允许参数 θ_μ 连接不同输出分量, 因为特征函数和元特征函数现在也带有指定输出分量的向量指标.²³⁸

第三, 本章反复提到, 网络输出更新的领先有限宽度贡献包含 $O(\eta^3)$ 项. 为捕捉这些效应, 需要把二次模型 (11.105) 形变为**三次模型**:

$$z_i(x_\delta; \theta) = \sum_{\mu=1}^P \theta_\mu \widehat{\phi}_{i, \mu}(x_\delta) + \frac{1}{2} \sum_{\mu, \nu=1}^P \theta_\mu \theta_\nu \widehat{\psi}_{i, \mu \nu}(x_\delta) + \frac{1}{6} \sum_{\mu, \nu, \rho=1}^P \theta_\mu \theta_\nu \theta_\rho \widehat{\Psi}_{i, \mu \nu \rho}(x_\delta). \quad (11.151)$$

这里随机的**元元特征函数**由网络输出的三阶导数给出:

$$\widehat{\Psi}_{i, \mu \nu \rho}(x_\delta) \equiv \frac{d^3 z_{i; \delta}^{(L)}}{d\theta_\mu d\theta_\nu d\theta_\rho}; \quad (11.152)$$

²³⁷ 这里稍一般的元核定义, 应理解为类似于稍一般的核定义 (10.136).

²³⁸ 这些特征函数可能受到约束, 参见随机特征 (10.139) 的显式形式. 这些约束最终使无限宽度模型不接线, 却允许任一有限宽度网络的预测接线; 它们可视为一种权重绑定.

三次项使元特征能有效地像线性模型那样演化，同时使特征有效地像二次模型那样演化。²³⁹ 总之，对深度 $L > 1$ 的有限宽度网络，稍不极简的模型 (11.151) 是一种自洽描述，其中包含随机特征 (11.147)、随机元特征 (11.145) 和随机元元特征 (11.152)。

深度学习：表征学习的非最小模型

表征学习是深度学习令人兴奋的重要原因。表征学习最小模型表明，实际上可以把学习的分析与深度的分析解耦：简单二次模型 (11.105) 对一般特征函数 $\phi_j(x)$ 和元特征函数 $\psi_{jk}(x)$ ，或对偶地对核 $k_{\delta_1\delta_2}$ 和元核 $\mu_{\delta_0\delta_1\delta_2}$ ，都展现非平凡表征学习。尤其是元核使从训练数据学习特征成为可能；我们希望这类更广泛的表征学习模型本身也具有理论和实践价值。

当然，深度学习是表征学习的非最小模型，而这些核与元核的结构确实重要。对深度神经网络，这些函数在联合预激活量-NTK-dNTK 分布 $p(z^{(L)}, \hat{H}^{(L)}, \widehat{dH}^{(L)} | \mathcal{D})$ 中编码的统计量，由表征群流递推控制——参见 §4、§8 和 §11.2——其细节由底层架构和超参数隐式决定。将函数逼近应用到特定领域或数据集时，选择 MLP 之外的架构可能带来巨大改进：RG 流就是深度学习架构的归纳偏置。²⁴⁰ 因而，即使在展现非平凡表征学习的模型集合中，初始特征、元特征等选择仍然非常重要。²⁴¹

深度学习的全部力量很可能来自深度——即多层深度模型中神经元相互作用诱导的表征群流——与学习——即有限宽度下非线性动力学相互作用诱导的表征学习——协同工作。本书提出的深度学习理论原理，正是使你能够完全一般地分析这两个不可约基本要素的原理。

²³⁹要精确建立此联系，小参数 ϵ 不应放在三次模型定义 (11.151) 中，而应放进控制随机元元特征模型的联合分布 $p(\hat{\phi}_{i,\mu}, \hat{\psi}_{i,\mu\nu}, \hat{\Psi}_{i,\mu\nu\rho})$ 的统计量中。示意地，非平凡组合为

$$\mathbb{E}[\hat{\phi}^2] = O(1), \quad \mathbb{E}[\hat{\psi}\hat{\phi}^2z] = O(\epsilon), \quad \mathbb{E}[\hat{\Psi}\hat{\phi}^3] = O(\epsilon), \quad \mathbb{E}[\hat{\psi}^2\hat{\phi}^2] = O(\epsilon). \quad (11.153)$$

下一章会分别把这些组合对应到 NTK、dNTK 和即将揭示的两个 ddNTK。重要的是，它们全都具有相同的 $\epsilon = L/n$ 阶；为自洽描述有限宽度网络，必须把它们视为三次模型。

²⁴⁰只要其他深度学习架构允许围绕无限宽度（或无限通道数、无限头数）极限展开，本节的非线性模型与近核方法形式体系也应描述它们。关于表征学习和训练动力学的结论都可沿用；区别只在于函数 $\phi_{i,\mu}(x)$ 、 $\psi_{i,\mu\nu}(x)$ 不同，因而核与元核 $k_{i_1i_2;\delta_1\delta_2}$ 、 $\mu_{i_0i_1i_2;\delta_0\delta_1\delta_2}$ 由不同于本书所研究的一组递推构造。

²⁴¹附录 B 将通过研究残差网络直接探讨这一问题的一个方面：这类网络允许引入一个参数，在单个网络中权衡更多层的表征群流与系综中更多的有效实现。

第 ∞ 章

训练的终点

科学家的工作是仔细聆听自然，而不是告诉自然该如何行事。

Freeman Dyson 解释 Richard Feynman 的研究方式，见 [69].

本章终于要完成有限宽度网络的领先阶有效理论分析，并求解其梯度下降训练动力学。无限宽度极限的解与训练算法无关；与之相反，这类深度网络的动力学具有丰富的现象学，捕捉了有用特征在训练过程中形成的不同方式。训练动力学的解给出了充分训练的有限宽度网络系综的第一性原理描述，实现了本书的一个主要目标。

遗憾的是，两项自然事实会打断我们的工作：(i) 为了在 $1/n$ 阶自洽地描述训练动力学，必须纳入两个附加对象；它们分别来自网络输出更新展开至三阶、NTK 更新展开至二阶以及 dNTK 更新展开至一阶；(ii) 由于缺乏光滑性，我们无法描述 ReLU 网络的动力学，也无法描述尺度不变普适类中采用其他非线性激活函数的网络动力学。

关于第一点，尽管二次模型语境中的表征学习分析颇具启发性，我们已经预告过，它不足以捕捉有限宽度网络的具体细节。特别地，在 $1/n$ 领先阶还存在两个 NTK 微分，称为 $ddNTK$ 。推导这些 $ddNTK$ 的随机前向方程、递推和有效理论虽然直接，却相当繁琐，已经没有教学价值。因此不再给出推导细节——关于预激活量、NTK 和 dNTK，你已经分别在 §4–§5、§8–§9 以及 §11.2–§11.3 中三次见过这些操作——这里只陈述结果，把细节留作一种训练后的测试；毕竟，你的训练也已经到了终点。

关于第二点，为了对 ReLU 之类的非光滑激活函数给出特殊说明，本书始终不得不采用特殊方法。在我们看来，ReLU 目前是最流行的激活函数之一，这足以说明额外工作的合理性。然而，我们终于用尽技巧，只能放弃：原因很容易解释，当全局学习率 η 的 Taylor 展开应用于由非光滑激活函数构成的网络动力学时，它会失效。我们只好追随社群方向，重新考虑 ReLU 的光滑版本——但只考虑允许某种临界性的版本，例如 GELU 与 SWISH。

说明这两项干扰后，我们将在 § $\infty.1$ 给出 $ddNTK$ 的所有相关结果：定义它们，给出张量分解，并解释其宽度与深度标度；无关细节则藏在本章末尾的 § $\infty.3$ 。若你一直认真阅读，就不会惊讶：经过适当归一化后， $ddNTK$ 按有效理论截断 ℓ/n 标度。这一标度表明，为理解深度 MLP 的领先有限宽度动力学，需要考虑预激活量–NTK–dNTK– $ddNTK$ 的联合统计。重要的是，这些 $ddNTK$ 赋予 dNTK 自身的动力学；从 §11.4.1 的参数空间视角看，这意味着模型的元特征函数现在也会演化。

陈述这些结果后，我们将在 § $\infty.2$ 回归原定的教学安排，终于求解有限宽度下的训练动力学。在沿无限宽度巨大飞跃出现一次错误起步后，首先在 § $\infty.2.1$ 学习如何在经

过调整的巨大飞跃之后迈出一小步，从而得到第一个有限宽度解. 接着在 §∞.2.2 分析普通梯度下降的许许多多步，得到第二个有限宽度解. 有限宽度下的非线性动力学最终使充分训练的解依赖训练算法，所以这两个小节所得解存在有意义的差异.

特别地，充分训练的有限宽度网络的函数逼近可分解为与优化细节无关的普适部分，以及一组算法投影算子；其函数形式编码了解对训练算法的全部依赖. 这些投影算子给出学习算法的对偶样本空间视角，类似于模型参数与不同核之间的关系.

相应地，在 §∞.2.3 中，我们将讨论这些投影算子如何影响解，从而把训练动力学的归纳偏置与网络架构的归纳偏置分开理解. 还将进一步分析充分训练网络作出的预测，考察表征学习增强与不同实例间涨落随网络深度增大而增强之间的权衡.

尽管这是正文的最后一章，随后的短结语 ε 将从有效理论的宏观视角探讨如何定义过参数化网络的模型复杂度. 随后两个附录还会涉及主线之外的若干主题. 附录 A 将介绍信息论框架，为估计区分有效深网络与过深网络的最优纵横比提供工具. 附录 B 将用有效理论方法研究残差网络，说明它们如何把有效深网络的范围扩展到越来越大的深度.

∞.1 另外两个微分

这是谁订的？

I. I. Rabi 对 $O(1/n)$ 的 ddNTK 所作的打趣.

最后一次，让我们展开参数更新后的第 ℓ 层预激活量，这次保留到三阶：

$$\begin{aligned} \vec{d}z_{i;\delta}^{(\ell)} &\equiv z_{i;\delta}^{(\ell)}(t=1) - z_{i;\delta}^{(\ell)}(t=0) \\ &= \sum_{\ell_1=1}^{\ell} \sum_{\mu} \frac{dz_{i;\delta}^{(\ell)}}{d\theta_{\mu}^{(\ell_1)}} \vec{d}\theta_{\mu}^{(\ell_1)} + \frac{1}{2} \sum_{\ell_1, \ell_2=1}^{\ell} \sum_{\mu_1, \mu_2} \frac{d^2 z_{i;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} \vec{d}\theta_{\mu_1}^{(\ell_1)} \vec{d}\theta_{\mu_2}^{(\ell_2)} \\ &\quad + \frac{1}{6} \sum_{\ell_1, \ell_2, \ell_3=1}^{\ell} \sum_{\mu_1, \mu_2, \mu_3} \frac{d^3 z_{i;\delta}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)} d\theta_{\mu_3}^{(\ell_3)}} \vec{d}\theta_{\mu_1}^{(\ell_1)} \vec{d}\theta_{\mu_2}^{(\ell_2)} \vec{d}\theta_{\mu_3}^{(\ell_3)} + \dots \end{aligned} \quad (\infty.1)$$

对梯度下降，还要回忆，利用链式法则 (11.3) 后，任一具体网络第 ℓ_a 层参数的变化由 (11.4) 给出：

$$\vec{d}\theta_{\mu}^{(\ell_a)} = -\eta \sum_{\nu} \lambda_{\mu\nu}^{(\ell_a)} \left(\sum_{j,k,\tilde{\alpha}} \frac{\partial \mathcal{L}_A}{\partial z_{k;\tilde{\alpha}}^{(L)}} \frac{dz_{k;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(\ell)}} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_{\nu}^{(\ell_a)}} \right) = -\eta \sum_{\nu,j,\tilde{\alpha}} \lambda_{\mu\nu}^{(\ell_a)} \epsilon_{j;\tilde{\alpha}}^{(\ell)} \frac{dz_{j;\tilde{\alpha}}^{(\ell)}}{d\theta_{\nu}^{(\ell_a)}}, \quad (\infty.2)$$

这里沿用 §11.1 的约定，明确标出各参数所属层. 还要回忆，学习率张量 $\lambda_{\mu\nu}^{(\ell)}$ 只连接同一层 ℓ 内的参数. 上式中 ℓ 是满足 $\ell_a \leq \ell$ 的中间层，并使用了第 ℓ 层误差因子 (11.5)：

$$\epsilon_{j;\tilde{\alpha}}^{(\ell)} \equiv \sum_{k=1}^{n_L} \frac{\partial \mathcal{L}_A}{\partial z_{k;\tilde{\alpha}}^{(L)}} \frac{dz_{k;\tilde{\alpha}}^{(L)}}{dz_{j;\tilde{\alpha}}^{(\ell)}} = \frac{d\mathcal{L}_A}{dz_{j;\tilde{\alpha}}^{(\ell)}}. \quad (\infty.3)$$

将参数更新 (∞.2) 代回预激活量更新 (∞.1), 可写成

$$\begin{aligned} \dot{z}_{i;\delta}^{(\ell)} = & -\eta \sum_{j,\tilde{\alpha}} \widehat{H}_{ij;\delta\tilde{\alpha}}^{(\ell)} \epsilon_{j;\tilde{\alpha}}^{(\ell)} + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)} \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} \\ & - \frac{\eta^3}{6} \sum_{j_1,j_2,j_3,\tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3} \widehat{dd_I H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(\ell)} \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} \epsilon_{j_3;\tilde{\alpha}_3}^{(\ell)}, \\ & + O(\eta^4) \end{aligned} \quad (\infty.4)$$

前两项已在上一章 (11.9) 得到; 三次项是新的, 其中第一个 **ddNTK** 定义为

$$\widehat{dd_I H}_{i_0i_1i_2i_3;\delta_0\delta_1\delta_2\delta_3}^{(\ell)} \equiv \sum_{\ell_1,\ell_2,\ell_3=1}^{\ell} \sum_{\substack{\mu_1,\nu_1, \\ \mu_2,\nu_2, \\ \mu_3,\nu_3}} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \lambda_{\mu_3\nu_3}^{(\ell_3)} \frac{d^3 z_{i_0;\delta_0}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)} d\theta_{\mu_3}^{(\ell_3)}} \frac{dz_{i_1;\delta_1}^{(\ell)}}{d\theta_{\nu_1}^{(\ell_1)}} \frac{dz_{i_2;\delta_2}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}} \frac{dz_{i_3;\delta_3}^{(\ell)}}{d\theta_{\nu_3}^{(\ell_3)}}. \quad (\infty.5)$$

与往常一样, **ddNTK** 上的帽号表示它是随机的, 依赖初始化时模型参数的具体实现. 与 **dNTK** 类似, 这个 **ddNTK** 在第二、第三、第四组配对指标 $(i_1, \delta_1) \leftrightarrow (i_2, \delta_2) \leftrightarrow (i_3, \delta_3)$ 下完全对称, 而第一组神经元-样本指标 (i_0, δ_0) 与其余三组不同.

展开至 η^3 阶后, 更新 (∞.4) 成为误差因子的三次函数. 第一个 **ddNTK** 在初始化时的统计量为 $O(1/n)$, 故必须展开到这一阶并纳入分析. 更高阶更新项均为次领先项, 因此可在此式中将 $O(\eta^4)$ 替换为 $O(1/n^2)$.

正如把预激活量更新展开至 η^2 阶时, 必须把 **NTK** 更新展开至 η 阶; 现在为了使三次更新 (∞.4) 的动力学自洽, 必须把 **NTK** 更新展开至 η^2 阶:

$$\begin{aligned} dH_{i_1i_2;\delta_1\delta_2}^{(\ell)} & \equiv H_{i_1i_2;\delta_1\delta_2}^{(\ell)}(t=1) - H_{i_1i_2;\delta_1\delta_2}^{(\ell)}(t=0) \\ & = \sum_{\ell_1=1}^{\ell} \sum_{\mu_1} \frac{dH_{i_1i_2;\delta_1\delta_2}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)}} d\theta_{\mu_1}^{(\ell_1)} + \sum_{\ell_1,\ell_2=1}^{\ell} \sum_{\mu_1,\mu_2} \frac{d^2 H_{i_1i_2;\delta_1\delta_2}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)}} d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_2}^{(\ell_2)} + \dots \\ & = -\eta \sum_{j,\tilde{\alpha}} \left(\widehat{dH}_{i_1i_2j;\delta_1\delta_2\tilde{\alpha}}^{(\ell)} + \widehat{dH}_{i_2i_1j;\delta_2\delta_1\tilde{\alpha}}^{(\ell)} \right) \epsilon_{j;\tilde{\alpha}}^{(\ell)} \\ & \quad + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \left[\widehat{dd_I H}_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)} + \widehat{dd_I H}_{i_2i_1j_1j_2;\delta_2\delta_1\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)} \right] \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} \\ & \quad + \eta^2 \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{dd_{II} H}_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2}^{(\ell)} \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} + O(\eta^3). \end{aligned} \quad (\infty.6)$$

最后一个等号中, 代入 **NTK** 定义 (11.7) 与参数更新 (∞.2), 计算导数后收集各项. 由此识别出第二个 **ddNTK**:

$$\widehat{dd_{II} H}_{i_1i_2i_3i_4;\delta_1\delta_2\delta_3\delta_4}^{(\ell)} \equiv \sum_{\ell_1,\ell_2,\ell_3=1}^{\ell} \sum_{\substack{\mu_1,\nu_1, \\ \mu_2,\nu_2, \\ \mu_3,\nu_3}} \lambda_{\mu_1\nu_1}^{(\ell_1)} \lambda_{\mu_2\nu_2}^{(\ell_2)} \lambda_{\mu_3\nu_3}^{(\ell_3)} \frac{d^2 z_{i_1;\delta_1}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)} d\theta_{\mu_3}^{(\ell_3)}} \frac{d^2 z_{i_2;\delta_2}^{(\ell)}}{d\theta_{\mu_2}^{(\ell_2)} d\theta_{\nu_3}^{(\ell_3)}} \frac{dz_{i_3;\delta_3}^{(\ell)}}{d\theta_{\nu_1}^{(\ell_1)}} \frac{dz_{i_4;\delta_4}^{(\ell)}}{d\theta_{\nu_2}^{(\ell_2)}}. \quad (\infty.7)$$

帽号表示该 ddNTK 在初始化时同样是随机的；很快将说明，其领先统计量也为 $O(1/n)$. $\widehat{\text{dd}}_{\Pi} H_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}$ 的对称性约束更强：它只在联合交换 $(i_1, \delta_1) \leftrightarrow (i_2, \delta_2)$ 以及 $(i_3, \delta_4) \leftrightarrow (i_4, \delta_4)$ 下对称. 但这也意味着可作如下指标交换：

$$\sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} \widehat{\text{dd}}_{\Pi} H_{i_1 i_2 j_1 j_2; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2}^{(\ell)} \epsilon_{j_1; \tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2; \tilde{\alpha}_2}^{(\ell)} = \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} \widehat{\text{dd}}_{\Pi} H_{i_2 i_1 j_1 j_2; \delta_2 \delta_1 \tilde{\alpha}_1 \tilde{\alpha}_2}^{(\ell)} \epsilon_{j_1; \tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2; \tilde{\alpha}_2}^{(\ell)}, \quad (\infty.8)$$

NTK 更新 (∞.6) 的最后一行正是用它化简的.

总体上，NTK 更新现在是误差因子的二次函数，使动力学发生耦合并具有非线性. 两个 ddNTK 在初始化时的统计量均为 $O(1/n)$ ，故必须纳入分析. NTK 更新中的更高阶项为次领先项，因此在 (∞.6) 中可将 $O(\eta^3)$ 替换为 $O(1/n^2)$.

最后，考虑 dNTK 的领先阶更新：

$$\begin{aligned} \bar{d}dH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)} &\equiv dH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)}(t=1) - dH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)}(t=0) \\ &= \sum_{\ell_1=1}^{\ell} \sum_{\mu_1} \frac{ddH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}^{(\ell)}}{d\theta_{\mu_1}^{(\ell_1)}} d\theta_{\mu_1}^{(\ell_1)} + \dots \\ &= -\eta \sum_{j, \tilde{\alpha}} \left(\widehat{\text{dd}}_{\text{I}} H_{i_0 i_1 i_2 j; \delta_0 \delta_1 \delta_2 \tilde{\alpha}}^{(\ell)} + \widehat{\text{dd}}_{\Pi} H_{i_0 i_1 i_2 j; \delta_0 \delta_1 \delta_2 \tilde{\alpha}}^{(\ell)} + \widehat{\text{dd}}_{\Pi} H_{i_0 i_2 i_1 j; \delta_0 \delta_2 \delta_1 \tilde{\alpha}}^{(\ell)} \right) \epsilon_{j; \tilde{\alpha}}^{(\ell)} \\ &\quad + O(\eta^2). \end{aligned} \quad (\infty.9)$$

最后一个等号代入 dNTK 定义 (11.8) 与参数更新 (∞.2)，求导后用 ddNTK 定义 (∞.5)、(∞.7) 收集各项. dNTK 更新是误差因子的线性函数，动力学最为简单. 更高阶项为次领先项，故在 (∞.9) 中可将 $O(\eta^2)$ 替换为 $O(1/n^2)$. 对 $\bar{d}dH$ 这一记号我们深表歉意，并保证不再使用.

更新 (∞.4)、(∞.6) 和 (∞.9) 构成 $O(1/n)$ 阶有限宽度更新的完全集合. 为继续分析，需要求出 ddNTK 的领先阶统计量.

ddNTK 统计量

为求充分训练的有限宽度网络的分布，需要网络输出、NTK、dNTK 与 ddNTK 的联合分布：

$$p\left(z^{(L)}, \hat{H}^{(L)}, \widehat{d}H^{(L)}, \widehat{\text{dd}}_{\text{I}} H^{(L)}, \widehat{\text{dd}}_{\Pi} H^{(L)} \middle| \mathcal{D}\right). \quad (\infty.10)$$

这里不再推演细节，而把它们留在我们自己的私人笔记本中. 你已经拥有所需的全部工具：可仿照 §4、§8 和 §11.2，利用表征群流求出递推；也可仿照 §5、§9 和 §11.3，求出调谐至临界性后初始化时有效理论的细节. 该分布 (∞.10) 的完整细节见本章末尾的 §∞.3. 这里将突出说明理解下一节动力学计算所需的结果.

求出两个 ddNTK 的随机前向方程后——若对此感到好奇，不妨向后翻看 (∞.174) 和 (∞.175)——还需找出其统计量的递推. 对这些张量，领先阶统计量来自其均值；交叉相关与方差都是次领先的. 计算每个 ddNTK 的均值时，适宜将其分解成如下仅含样

本指标的一组张量:

$$\mathbb{E} \left[\widehat{\text{ddI}} H_{i_0 i_1 i_2 i_3; \delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} \right] \equiv \frac{1}{n_{\ell-1}} \left[\delta_{i_0 i_1} \delta_{i_2 i_3} R_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} + \delta_{i_0 i_2} \delta_{i_3 i_1} R_{\delta_0 \delta_2 \delta_3 \delta_1}^{(\ell)} + \delta_{i_0 i_3} \delta_{i_1 i_2} R_{\delta_0 \delta_3 \delta_1 \delta_2}^{(\ell)} \right], \quad (\infty.11)$$

$$\mathbb{E} \left[\widehat{\text{ddII}} H_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} \right] \equiv \frac{1}{n_{\ell-1}} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} S_{\delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} + \delta_{i_1 i_3} \delta_{i_4 i_2} T_{\delta_1 \delta_3 \delta_4 \delta_2}^{(\ell)} + \delta_{i_1 i_4} \delta_{i_2 i_3} U_{\delta_1 \delta_4 \delta_2 \delta_3}^{(\ell)} \right]. \quad (\infty.12)$$

因此, 需要确定递推并计算深度标度的新对象共有四个.

与 dNTK 一样, 两个 ddNTK 在第一层均为零. 随后从第二层推进至更深层, 经过一大堆繁琐代数, 并在书中反复翻找以作各种代换, 可分别得到 $R^{(\ell)}$ 、 $S^{(\ell)}$ 、 $T^{(\ell)}$ 和 $U^{(\ell)}$ 的递推: (∞.177)、(∞.179)、(∞.180) 和 (∞.181). 你可以向后翻看, 但多半不会想看.... 重要的是, 这些递推与分解 (∞.11) 和 (∞.12) 共同表明, 两个 ddNTK 都具有非平凡的 $1/n$ 阶统计量:

$$\mathbb{E} \left[\widehat{\text{ddI}} H_{i_0 i_1 i_2 i_3; \delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} \right] = O\left(\frac{1}{n}\right), \quad \mathbb{E} \left[\widehat{\text{ddII}} H_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} \right] = O\left(\frac{1}{n}\right). \quad (\infty.13)$$

因此, 正如我们一直预告的那样, 必须在有限宽度训练动力学分析中纳入它们.

聚焦单输入统计量, 再次作与层无关的选择 $C_b^{(\ell)} = C_b$ 、 $C_W^{(\ell)} = C_W$ 和 $n_1 = \dots = n_{L-1} \equiv n$. 忽略 $1/n$ 的次领先贡献, 特别是用核替换平均度量 $G^{(\ell)} \rightarrow K^{(\ell)}$, 并用冻结 NTK 替换 NTK 均值 $H^{(\ell)} \rightarrow \Theta^{(\ell)}$, 四个递推 (∞.177)、(∞.179)、(∞.180) 和 (∞.181) 便一起约化为至少能放进一页的形式:

$$\begin{aligned} R^{(\ell+1)} &= \left(\chi_{\perp}^{(\ell)} \right)^2 R^{(\ell)} \\ &\quad + \lambda_W^{(\ell+1)} C_W \langle \sigma'' \sigma' \sigma' \sigma \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^2 + C_W^2 \langle \sigma''' \sigma' \sigma' \sigma' \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^3 \\ &\quad + \chi_{\perp}^{(\ell)} \left(\lambda_W^{(\ell+1)} \langle \sigma'' \sigma \rangle_{K^{(\ell)}} + C_W \Theta^{(\ell)} \langle \sigma''' \sigma' \rangle_{K^{(\ell)}} \right) (B^{(\ell)} + P^{(\ell)}) \\ &\quad + \chi_{\perp}^{(\ell)} \left(\lambda_W^{(\ell+1)} \langle \sigma' \sigma' \rangle_{K^{(\ell)}} + C_W \Theta^{(\ell)} \langle \sigma'' \sigma'' \rangle_{K^{(\ell)}} \right) P^{(\ell)}, \end{aligned} \quad (\infty.14)$$

$$\begin{aligned} S^{(\ell+1)} &= \left(\chi_{\perp}^{(\ell)} \right)^2 S^{(\ell)} \\ &\quad + C_W \lambda_W^{(\ell+1)} \langle \sigma' \sigma' \sigma' \sigma' \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^2 + C_W^2 \langle \sigma'' \sigma'' \sigma' \sigma' \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^3 \\ &\quad + \chi_{\perp}^{(\ell)} \left[\lambda_W^{(\ell+1)} \langle \sigma' \sigma' \rangle_{K^{(\ell)}} + C_W \Theta^{(\ell)} \langle \sigma'' \sigma'' \rangle_{K^{(\ell)}} \right] B^{(\ell)}, \end{aligned} \quad (\infty.15)$$

$$\begin{aligned} T^{(\ell+1)} &= \left(\chi_{\perp}^{(\ell)} \right)^2 T^{(\ell)} \\ &\quad + 2C_W \lambda_W^{(\ell+1)} \langle \sigma'' \sigma' \sigma' \sigma \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^2 + C_W^2 \langle \sigma'' \sigma'' \sigma' \sigma' \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^3 \\ &\quad + \left(\lambda_W^{(\ell+1)} \right)^2 \langle \sigma' \sigma' \sigma \sigma \rangle_{K^{(\ell)}} \Theta^{(\ell)} \\ &\quad + \left(\lambda_W^{(\ell+1)} \langle z \sigma' \sigma \rangle_{K^{(\ell)}} + C_W \Theta^{(\ell)} \langle z \sigma'' \sigma' \rangle_{K^{(\ell)}} \right)^2 \frac{F^{(\ell)}}{(K^{(\ell)})^2} \\ &\quad + 2\chi_{\perp}^{(\ell)} \left[\lambda_W^{(\ell+1)} (\langle \sigma'' \sigma \rangle_{K^{(\ell)}} + \langle \sigma' \sigma' \rangle_{K^{(\ell)}}) + C_W \Theta^{(\ell)} (\langle \sigma''' \sigma' \rangle_{K^{(\ell)}} + \langle \sigma'' \sigma'' \rangle_{K^{(\ell)}}) \right] Q^{(\ell)}, \end{aligned} \quad (\infty.16)$$

$$U^{(\ell+1)} = \left(\chi_{\perp}^{(\ell)} \right)^2 U^{(\ell)} + C_W^2 \langle \sigma'' \sigma'' \sigma' \sigma' \rangle_{K^{(\ell)}} (\Theta^{(\ell)})^3. \quad (\infty.17)$$

这里还回忆两个敏感度 (5.50) 和 (5.51)，以化简这些表达式：

$$\chi_{\parallel}^{(\ell)} \equiv \frac{C_W}{K^{(\ell)}} \langle \sigma' \sigma z \rangle_{K^{(\ell)}}, \quad \chi_{\perp}^{(\ell)} \equiv C_W \langle \sigma' \sigma' \rangle_{K^{(\ell)}}. \quad (\infty.18)$$

ddNTK 标度

现在调谐至临界性，并用标度假设 (5.93) 求出临界指数 p_R 、 p_S 、 p_T 和 p_U ；它们分别描述 $R^{(\ell)}$ 、 $S^{(\ell)}$ 、 $T^{(\ell)}$ 和 $U^{(\ell)}$ 的渐近深度标度。

为理解这些控制 ddNTK 均值的张量之间的相对大小，还需再次确定适当的无量纲比。仿照 dNTK 讨论中的量纲分析逻辑，参见 (11.63)，考察预激活量的三阶更新 (∞.4)。再次牢记，只有量纲相同的项才能相加，于是

$$[z] = [\eta] [\epsilon] [\widehat{H}] = [\eta]^2 [\epsilon]^2 [\widehat{dH}] = [\eta]^3 [\epsilon]^3 [\widehat{dd_I H}] = [\eta]^3 [\epsilon]^3 [\widehat{dd_{II} H}]. \quad (\infty.19)$$

由第一个等式，仍有 $[\eta] [\epsilon] = [z] [\widehat{H}]^{-1}$ ，所以 R 、 S 、 T 和 U 的量纲均为 NTK 的三次方：

$$[R] \equiv [\widehat{dd_I H}] = [\widehat{H}]^3 [z]^{-2}, \quad [S] = [T] = [U] \equiv [\widehat{dd_{II} H}] = [\widehat{H}]^3 [z]^{-2}. \quad (\infty.20)$$

这意味着 ddNTK 的适当无量纲组合为

$$\frac{R^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_R + p_0 - 3p_{\Theta}}, \quad \frac{S^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_S + p_0 - 3p_{\Theta}}, \quad (\infty.21)$$

$$\frac{T^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_T + p_0 - 3p_{\Theta}}, \quad \frac{U^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} \sim \frac{1}{n} \left(\frac{1}{\ell} \right)^{p_U + p_0 - 3p_{\Theta}}, \quad (\infty.22)$$

为得到归一化比值，这里乘以核 $K^{(\ell)}$ 以计入 $[z]^{-2}$ ，再除以冻结 NTK $\Theta^{(\ell)}$ 的三个因子。其中 p_0 是核的临界指数， p_{Θ} 是 NTK 的临界指数。

最后稍作旁述，讨论量纲中一个此前一直忽略、但很快会变得重要的方面。特别地，由于网络输出 z 被设为真实输出 y ，二者实际应具有相同量纲：

$$[z] = [y]. \quad (\infty.23)$$

然而，预激活量的领先深度标度由核给出，

$$\mathbb{E} [z^{(\ell)} z^{(\ell)}] = K^{(\ell)} \sim \left(\frac{1}{\ell} \right)^{p_0}, \quad (\infty.24)$$

而真实输出 y 固定不变，不随深度标度。比较不同深度网络的性能时，这表明重新标度最终网络输出可能会有所帮助：

$$z_{i;\delta} \rightarrow z_{i;\delta} \left(\frac{1}{L} \right)^{-p_0/2}, \quad (\infty.25)$$

这实际上把整体网络输出的标度固定为 $p_0 = 0$ ；等价地，也可将训练输出重新标度为

$$y_{i;\tilde{\alpha}} \rightarrow y_{i;\tilde{\alpha}} \left(\frac{1}{L} \right)^{p_0/2}. \quad (\infty.26)$$

在 §∞.2.3 中还会进一步看到，这如何影响充分训练的网络在测试集上的预测。²⁴²

²⁴²对于想要学习实数向量的回归任务，这种重新标度是合适的。对于想要学习离散概率分布的分类任务，应像 (10.37) 那样，重新标度网络输出（在任何 softmax 层之前）或原始输出目标 $y_{i;\delta}$ （同样在任何 softmax 层之前）。

$K^* = 0$ 普适类

对于 $K^* = 0$ 普适类，回忆我们曾将激活函数作泰勒展开：

$$\sigma(z) = \sum_{p=0}^{\infty} \frac{\sigma_p}{p!} z^p, \quad (\infty.27)$$

并为方便起见定义了如下泰勒系数：

$$a_1 \equiv \left(\frac{\sigma_3}{\sigma_1} \right) + \frac{3}{4} \left(\frac{\sigma_2}{\sigma_1} \right)^2, \quad (\infty.28)$$

而且要求该类中的所有激活函数都满足 $\sigma_0 = 0$ 和 $\sigma_1 \neq 0$.

为求解单输入 ddNTK 递推关系 (∞.14)–(∞.17)，需要计算几个新的高斯期望，尤其应注意，其中一些期望现在依赖于激活函数的三阶导数。最后，为调谐至 $K^* = 0$ 临界性 (5.90)，需要把初始化超参数设为 $C_b = 0$ 和 $C_W = 1/\sigma_1^2$ ；为实现学习率等价原理，则需按照 (9.95) 将训练超参数设为

$$\lambda_b^{(\ell)} = \tilde{\lambda}_b \left(\frac{1}{\ell} \right)^{p_{\perp}}, \quad \lambda_W^{(\ell)} = \tilde{\lambda}_W \left(\frac{L}{\ell} \right)^{p_{\perp}-1}. \quad (\infty.29)$$

为简单起见，还把讨论限于奇激活函数，例如 $\tanh$ ；重要的是，对这类函数有 $\sigma_2 = 0$ 和 $p_{\perp} = 1$.

考察单输入 ddNTK 递推关系 (∞.14)–(∞.17)，可以看到，它们依赖于预激活量的高斯期望，以及此前考察的所有其他对象的解：NTK 方差、NTK–预激活量互相关和 dNTK–预激活量互相关。按需代入所有这些量的解——尽管读者需要前后翻阅才能找到它们，但 dNTK 分析所需的大多数结果已重印于 §11.3.2——便可得到所有单输入 ddNTK 递推关系的解：

$$R^{(\ell)} = -\frac{\ell^2}{48} \left[3\tilde{\lambda}_b + 4\frac{\tilde{\lambda}_W\sigma_1^2}{(-a_1)} \right] \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W\sigma_1^2}{(-a_1)} \right]^2 (-a_1) + \dots, \quad (\infty.30)$$

$$S^{(\ell)} = \frac{\ell^2}{12} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W\sigma_1^2}{(-a_1)} \right]^2 \tilde{\lambda}_W\sigma_1^2 + \dots, \quad (\infty.31)$$

$$T^{(\ell)} = \frac{\ell^2}{32} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W\sigma_1^2}{(-a_1)} \right] (-a_1) \tilde{\lambda}_b^2 + \dots, \quad (\infty.32)$$

$$U^{(\ell)} = \frac{1}{2} \left[\tilde{\lambda}_b + \frac{\tilde{\lambda}_W\sigma_1^2}{(-a_1)} \right]^3 (-a_1) + \dots. \quad (\infty.33)$$

由此可读出临界指数 $p_R = p_S = p_T = -2$ 和 $p_U = 0$ ，并且无量纲比为

$$\frac{R^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = -\frac{1}{48} \left[\frac{3\tilde{\lambda}_b + 4\tilde{\lambda}_W \sigma_1^2 / (-a_1)}{\tilde{\lambda}_b + \tilde{\lambda}_W \sigma_1^2 / (-a_1)} \right] \frac{\ell}{n} + \dots, \quad (\infty.34)$$

$$\frac{S^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = \frac{1}{12} \left[\frac{\tilde{\lambda}_W \sigma_1^2 / (-a_1)}{\tilde{\lambda}_b + \tilde{\lambda}_W \sigma_1^2 / (-a_1)} \right] \frac{\ell}{n} + \dots, \quad (\infty.35)$$

$$\frac{T^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = \frac{1}{32} \left[\frac{\tilde{\lambda}_b}{\tilde{\lambda}_b + \tilde{\lambda}_W \sigma_1^2 / (-a_1)} \right]^2 \frac{\ell}{n} + \dots, \quad (\infty.36)$$

$$\frac{U^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = \frac{1}{2} \frac{1}{\ell n} + \dots. \quad (\infty.37)$$

这意味着， $R^{(\ell)}$ 、 $S^{(\ell)}$ 和 $T^{(\ell)}$ 都按照领先有效理论截断作如下标度：

$$p_R + p_0 - 3p_\Theta = -1 \quad p_S + p_0 - 3p_\Theta = -1, \quad p_T + p_0 - 3p_\Theta = -1. \quad (\infty.38)$$

因此可见， $K^* = 0$ 激活函数的领先阶有限宽度动力学既有来自第一 ddNTK（即 $\widehat{\text{dd}}_{\text{I}} H$ ）并经由 $R^{(\ell)}$ 给出的贡献，也有来自第二 ddNTK（即 $\widehat{\text{dd}}_{\text{II}} H$ ）并经由 $S^{(\ell)}$ 和 $T^{(\ell)}$ 给出的贡献。²⁴³

尺度不变普适类

关于非线性尺度不变激活函数 (2.13)，或许最需要记住的事实是

$$\sigma(z) = \begin{cases} a_+ z, & z \geq 0, \\ a_- z, & z < 0, \end{cases} \quad (\infty.39)$$

其中 $a_+ \neq -a_-$ ；这类函数并不光滑：其一阶导数是以原点为中心的阶跃函数，而二阶导数是狄拉克 delta 函数 (2.32)：

$$\sigma'(z) = \begin{cases} a_+, & z \geq 0, \\ a_-, & z < 0, \end{cases}, \quad \sigma''(z) = (a_+ - a_-) \delta(z), \quad (\infty.40)$$

而更高阶导数将涉及狄拉克 delta 函数的导数。

再次考察单输入 ddNTK 递推关系 (∞.14)–(∞.17)，这些激活函数的尖点，加上其中存在含有最高三阶 $\sigma(z)$ 导数的高斯期望，应当令人生畏；若读者留意了 §5.5 末尾的警告，就更是如此。事实上，若试图形式地计算其中一些期望，特别是 $\langle \sigma'' \sigma'' \rangle_K$ 以及通过分部积分与之相关的其他期望，就会发现它们趋于发散；即便动用物理学中所有可供支配、试图赋予发散积分以意义的魔法技巧，也是如此。²⁴⁴

²⁴³若放宽激活函数必须为奇函数的限制，则会发现 $R^{(\ell)}$ 、 $S^{(\ell)}$ 和 $T^{(\ell)}$ 具有相同的标度——尽管系数不同——而 $U^{(\ell)}$ 会大一个因子 ℓ ，但总体上仍是次领先的。

²⁴⁴在 §11.3.1 分析 dNTK 时，我们多少有些幸运：所需的全部高阶导数高斯积分都通过分部积分得到化简，并给出有限的——事实上为零的——答案，参见 (11.67) 和 (11.69)。

这些高斯关联子的发散实际上是在告诉我们：上述展开存在严重问题。这包括预激活量更新 (∞.4)、NTK 更新 (∞.6) 和 dNTK 更新 (∞.9)。特别地，对于这些非光滑激活函数，关于全局学习率 η 的泰勒展开会失效，无法准确描述网络如何更新。因此，求解有限宽度动力学的这套方法不适用于非线性尺度不变激活函数。

为理解原因，考虑一个极其简单的网络模型，即带偏置的单神经元：

$$z(x) = \sigma(x + b). \quad (\infty.41)$$

这里输入 x 和输出 z 都是标量，并取激活函数 $\sigma(z)$ 为 ReLU，即 $a_+ = 1, a_- = 0$ 。因而，对满足 $x + b > 0$ 的特定输入 x ，激活被触发，输出为 $z(x) = x + b$ ；对满足 $x' + b < 0$ 的特定输入 x' ，激活未被触发，输出为 $z(x') = 0$ 。

现在，考虑用一个使激活被触发的训练样本 $x > -b$ 对参数作梯度下降更新。此时偏置更新为

$$db = -\eta \frac{dz}{db} \epsilon = -\eta \epsilon = O(\eta), \quad (\infty.42)$$

其中 ϵ 是依赖于真实输出 y 的损失误差因子。若 $x + b + db > 0$ ，则输出变化为

$$dz = -\eta \epsilon = O(\eta), \quad (\infty.43)$$

这可由泰勒展开 (∞.4) 完美描述。然而，若训练误差足够大，以致 $x + b + db = x + b - \eta \epsilon < 0$ ，则激活关闭，并且

$$dz = -x - b = O(1). \quad (\infty.44)$$

重要的是，这一更新与展开参数 η 无关，而关于 η 的泰勒展开无法探测 $\eta = (x + b)/\epsilon$ 处的不连续性。

因此，对 ReLU 而言，每当某个激活越过其触发阈值时，它都可能以一种与 η 无关的方式对梯度下降更新产生贡献。从经验上看，若尝试测量由 ReLU 激活函数构成的深 MLP 的 NTK 更新，所得结果与展开 (∞.6) 完全不符。相反，对于适当归一化的量，会发现其宽度标度为 $\sim 1/\sqrt{n}$ ，深度标度则随 ℓ 线性增长，这与微扰形式体系所预期的 ℓ/n 标度相反。²⁴⁵ 由此只能遗憾地得出结论：必须放弃用这些方法描述非线性尺度不变激活函数的有限宽度动力学。

需要指出，关于非线性尺度不变激活函数的临界性与无限宽度训练动力学，此前讨论的一切都完全成立，并且已得到实验验证；有限宽度下非零 dNTK 的存在仍然表明 NTK 是动态的，并且有限宽度下存在表征学习。刚才所述问题只影响下一节将要进行的有限宽度网络训练动力学分析；泰勒展开的失效仅仅意味着，我们无法为这些非光滑激活函数的表征学习给出定量图景。²⁴⁶ 所以，若确实想理解这一问题，可能需要一种全新的方法。

²⁴⁵ 很容易猜想，这个 $\sim 1/\sqrt{n}$ 标度源自在梯度下降步骤之后， Ln 个隐藏层激活中某一个经历与 η 无关的 $O(1)$ 变化的概率累积，其中 $n \gg 1$ 。

²⁴⁶ 不过，我们的分析适用于 ReLU 的任何允许某种临界性的光滑版本，参见 §5.3.4 中对 SWISH 和 GELU 临界性的讨论。特别地，下一节将求出的训练动力学描述的正是这些网络。这些动力学解与其所有相关递推关系在输出层的解结合起来，将能在实践中准确刻画这种充分训练的一类 ReLU 网络。

这样一来, 整个尺度不变普适类中只剩下一类激活函数: 用于深线性网络的 **linear** 激活函数. 调谐至临界性, 即取 $C_b = 0$ 和 $C_W = 1$, 从而固定 $\chi = 1$, 并依照 (9.94) 选取与层无关的学习率

$$\lambda_b^{(\ell)} = \frac{\tilde{\lambda}_b}{L}, \quad \lambda_W^{(\ell)} = \frac{\tilde{\lambda}_W}{L}, \quad (\infty.45)$$

便可求解单输入 ddNTK 递推关系 (∞.14)–(∞.17). 注意, 在 U 递推 (∞.17) 的每一项中, 以及 R 递推 (∞.14) 中除一项外的所有项中, 激活函数的高斯期望都含有二阶或三阶导数, 而它们对 **linear** 函数均为零. R 递推中唯一不为零的那一项还乘以 $P^{(\ell)}$; 对所有尺度不变激活函数, 该量都为零, 参见 (11.74). 因此

$$R^{(\ell)} = 0, \quad U^{(\ell)} = 0, \quad (\infty.46)$$

尤其是, 第一 ddNTK, 即 $\widehat{\text{dd}_I H}$, 不会在 $O(1/n)$ 阶对深线性网络的动力学作出贡献, 因为它完全由 $R^{(\ell)}$ 决定. 然而, 对 S 递推 (∞.15) 和 T 递推 (∞.16), 会得到非平凡结果: 这些递推可精确求解为

$$S^{(\ell)} = \frac{\ell^2(\ell^2 - 1)}{12L^3} (\tilde{\lambda}_b + \tilde{\lambda}_W K^*)^2 \tilde{\lambda}_W, \quad (\infty.47)$$

$$T^{(\ell)} = \frac{\ell^2(\ell^2 - 1)}{12L^3} (\tilde{\lambda}_b + \tilde{\lambda}_W K^*) \tilde{\lambda}_W^2 K^*, \quad (\infty.48)$$

由此可见, 临界指数为 $p_S = p_T = -4$. 最后, 无量纲比为

$$\frac{S^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = \frac{1}{12} \left[\frac{\tilde{\lambda}_W K^*}{\tilde{\lambda}_b + \tilde{\lambda}_W K^*} \right] \frac{\ell}{n} + \dots, \quad (\infty.49)$$

$$\frac{T^{(\ell)} K^{(\ell)}}{n (\Theta^{(\ell)})^3} = \frac{1}{12} \left[\frac{\tilde{\lambda}_W K^*}{\tilde{\lambda}_b + \tilde{\lambda}_W K^*} \right]^2 \frac{\ell}{n} + \dots, \quad (\infty.50)$$

并可看到, 它们按照领先有效理论截断作如下标度:

$$p_S + p_0 - 3p_\Theta = -1, \quad p_T + p_0 - 3p_\Theta = -1. \quad (\infty.51)$$

总之, 第二 ddNTK, 即 $\widehat{\text{dd}_{II} H}$, 通过 $S^{(\ell)}$ 和 $T^{(\ell)}$ 在领先阶对深线性网络的动力学作出贡献.

∞.2 有限宽度下的训练

既然已经理解了预激活量、NTK、dNTK 与 ddNTK 的联合统计量, 我们几乎拥有了评估有限宽度、非零深度下完全训练网络分布所需的全部工具. 为说明原因, 回忆网络输出演化的有限宽度展开 (∞.4):

$$\begin{aligned} z_{i;\delta}^{(L)}(t=1) &= z_{i;\delta}^{(L)} - \eta \sum_{j,\tilde{\alpha}} \widehat{H}_{ij;\delta\tilde{\alpha}}^{(L)} \epsilon_{j;\tilde{\alpha}}^{(L)} + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)} \epsilon_{j_1;\tilde{\alpha}_1}^{(L)} \epsilon_{j_2;\tilde{\alpha}_2}^{(L)} \\ &\quad - \frac{\eta^3}{6} \sum_{j_1,j_2,j_3,\tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3} \widehat{\text{dd}_I H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} \epsilon_{j_1;\tilde{\alpha}_1}^{(\ell)} \epsilon_{j_2;\tilde{\alpha}_2}^{(\ell)} \epsilon_{j_3;\tilde{\alpha}_3}^{(\ell)} + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (\infty.52)$$

重要的是，网络更新 (∞.52) 右侧的所有量—— $z_{i;\delta}^{(L)}$ 、 $\widehat{H}_{ij;\delta\tilde{\alpha}}^{(L)}$ 、 $\epsilon_{j;\tilde{\alpha}}^{(L)}$ 、 $\widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)}$ 和 $\widehat{dd_I H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)}$ ——都在初始化时取值，因而完全由预激活量-NTK-dNTK-ddNTK 联合分布的统计量决定：

$$p\left(z^{(L)}, \widehat{H}^{(L)}, \widehat{dH}^{(L)}, \widehat{dd_I H}^{(L)}, \widehat{dd_{II} H}^{(L)} \middle| \mathcal{D}\right), \quad (\infty.53)$$

本书的大部分篇幅都用于详细求解这一分布。因此，正如先前在无限宽度下所做的那样 (§10)，如果我们能为网络的每个实现调谐单步梯度下降，使其恰好落在训练损失的最小值 $z_{i;\tilde{\alpha}}^{(L)}(t=1) = y_{i;\tilde{\alpha}}$ 上，就可以利用联合分布 (∞.53)，计算更新 (∞.52) 后完全训练网络输出的统计量。

更一般地，如果用 T 步梯度下降训练网络，使得

$$z_{i;\tilde{\alpha}}^{(L)}(t=T) = y_{i;\tilde{\alpha}}, \quad \text{for all } \tilde{\alpha} \in \mathcal{A}, \quad (\infty.54)$$

并且如果能够确定如何把这种完全训练网络在一般输入 $\delta \in \mathcal{D}$ 上的输出表示成初始化统计变量的泛函，

$$z_{i;\delta}^{(L)}(T) \equiv \left[z_{i;\delta}^{(L)}(t=T) \right] \left(z^{(L)}, \widehat{H}^{(L)}, \widehat{dH}^{(L)}, \widehat{dd_I H}^{(L)}, \widehat{dd_{II} H}^{(L)} \right), \quad (\infty.55)$$

那么就可以给出完全训练网络输出分布的解析表达式：

$$p(z^{(L)}(T)). \quad (\infty.56)$$

方程 (∞.54) 是我们的完全训练条件，而分布 (∞.56) 完整描述了训练终点处的有限宽度网络系综。从理论上理解这一分布，正是本书开篇 §0 所设定的目标。现在唯一还需推导的是泛函 (∞.55)；为此，必须先弄清楚应采取何种步骤才能完全训练这些有限宽度网络。

回忆 §10.2.2：在无限宽度极限下，完全训练网络解 (∞.55) 具有算法无关性，即训练终点处分布不依赖于优化算法的细节，因此理论分析可以采用任意算法。相比之下，在有限宽度下，完全训练解 (∞.55) 将具有**算法依赖性**：即便固定初始化统计变量以及与之相应的初始化和训练超参数，不同的完全训练解仍会依据训练网络所用具体优化算法的细节，对测试集给出不同预测。令人欣慰的是，解的形式仍具有普适形式，而具体训练算法的非普适细节由六个射影张量刻画，参见 (∞.154)。因而，通过求出这类解，我们仍能非常一般地研究有限宽度下完全训练网络的分布。

基于这一认识，本节将给出两种不同优化算法的完全训练解。首先，在 §∞.2.1 中，我们将采取两个类 Newton 步骤来满足完全训练条件 (∞.54)。对大型训练集而言，这种训练算法在实践中不可行，但它极具教学价值，突出展示了有限宽度网络为使训练误差最小化，必须如何使其表征适应训练数据。随后，在 §∞.2.2 中，我们将解析求解原始梯度下降在 $1/n$ 阶的动力学，并得到一个略有不同的完全训练有限宽度网络系综。这种算法不仅在实践中可实现，也很常用于优化真实神经网络，而相应的解正是对这类完全训练网络的实际理论描述。这些解共同帮助我们理解优化算法的细节会以何种方式影响相应的完全训练解。最后，在 §∞.2.3 中，我们将能一般地分析这些不同的完全训练网络对测试集中新样本所作的预测。

在本节中，我们将省去层指标以稍微简化记号，因为理解训练时只需关注 $\ell = L$ 层的网络输出。

有限宽度下的无限宽巨大飞跃

开始之前，先回顾我们在无限宽度下于 §10.2 所作的巨大飞跃. 从有限宽度这一更精细的视角来看，我们会发现这次飞跃实际上错过了最小值，留下了 $1/n$ 阶的训练误差. 不过，以新的眼光审视这次飞跃很有启发性，因为它能帮助我们看清如何修正这些误差，进一步减小有限宽度训练误差.

回忆 §10.2：为用单步完全训练无限宽网络，需要作如下二阶更新：

$$d\theta_\mu = - \sum_{\nu, \tilde{\alpha}_1, \tilde{\alpha}_2, i} \eta \lambda_{\mu\nu} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} \frac{dz_{i; \tilde{\alpha}_1}}{d\theta_\nu} (z_{i; \tilde{\alpha}_2} - y_{i; \tilde{\alpha}_2}), \quad (\infty.57)$$

我们曾从两种角度解释它：(i) 把它看作广义训练算法 (10.19)，优化标准 MSE 损失 (10.5)；或 (ii) 把它看作标准（张量型）梯度下降步骤 (7.11)，优化广义 MSE 损失 (10.22). 这里， $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 称为 Newton 张量；在对 (∞.57) 的第一种理解中，它可以解释为允许我们在训练样本空间中采取各向异性步骤.

在这种参数更新下，有限宽度网络输出演化为

$$\begin{aligned} & z_{i; \delta}(t=1) \\ &= z_{i; \delta} - \eta \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\delta \tilde{\alpha}_1} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{i; \tilde{\alpha}_2} - y_{i; \tilde{\alpha}_2}) - \eta \sum_{j, \tilde{\alpha}_1, \tilde{\alpha}_2} \widehat{\Delta H}_{ij; \delta \tilde{\alpha}_1} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j; \tilde{\alpha}_2} - y_{j; \tilde{\alpha}_2}) \\ &+ \frac{\eta^2}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4} \widehat{dH}_{ij_1 j_2; \delta \tilde{\alpha}_1 \tilde{\alpha}_2} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_3} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\ &- \frac{\eta^3}{6} \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \dots, \tilde{\alpha}_6} \widehat{dd_1 H}_{ij_1 j_2 j_3; \delta \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_4} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_5} \kappa^{\tilde{\alpha}_3 \tilde{\alpha}_6} \\ &\quad \times (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (\infty.58)$$

这里照例将 NTK 分解为均值与涨落：

$$\widehat{H}_{ij; \delta \tilde{\alpha}} \equiv \delta_{ij} H_{\delta \tilde{\alpha}} + \widehat{\Delta H}_{ij; \delta \tilde{\alpha}}. \quad (\infty.59)$$

对于这种更新，单步 $T=1$ 后的完全训练条件 (∞.54)

$$z_{i; \tilde{\alpha}}(t=1) = y_{i; \tilde{\alpha}}, \quad \text{for all } \tilde{\alpha} \in \mathcal{A}, \quad (\infty.60)$$

可写为

$$\begin{aligned} & z_{i; \tilde{\alpha}} - y_{i; \tilde{\alpha}} \\ &= \eta \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\tilde{\alpha} \tilde{\alpha}_1} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{i; \tilde{\alpha}_2} - y_{i; \tilde{\alpha}_2}) + \eta \sum_{j, \tilde{\alpha}_1, \tilde{\alpha}_2} \widehat{\Delta H}_{ij; \tilde{\alpha} \tilde{\alpha}_1} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j; \tilde{\alpha}_2} - y_{j; \tilde{\alpha}_2}) \\ &- \frac{\eta^2}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4} \widehat{dH}_{ij_1 j_2; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_3} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\ &+ \frac{\eta^3}{6} \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \dots, \tilde{\alpha}_6} \widehat{dd_1 H}_{ij_1 j_2 j_3; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_4} \kappa^{\tilde{\alpha}_2 \tilde{\alpha}_5} \kappa^{\tilde{\alpha}_3 \tilde{\alpha}_6} \\ &\quad \times (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (\infty.61)$$

新的巨大飞跃条件 (∞.61) 看起来或许有些令人生畏, 而且并不明显是否存在某种特定的 Newton 张量 $\kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 能让我们落到最小值上. 尽管如此, 我们仍预期无限宽解应当接近真正的有限宽解, 其误差为 $O(1/n)$.²⁴⁷

基于这一认识, 第一步先尝试无限宽巨大飞跃 (10.30), 看看会落到何处. 这个无限宽巨大飞跃可解释为 Newton 方法, 由二阶更新 (∞.57) 给出, 其中全局学习率与 Newton 张量的乘积取为

$$\eta \kappa^{\tilde{\alpha}_1 \tilde{\alpha}_2} = \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2}, \quad (\infty.62)$$

这里, NTK 均值子矩阵的逆 $\tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 由下式隐式定义:

$$\sum_{\tilde{\alpha}_2 \in \mathcal{A}} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{H}_{\tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1}. \quad (\infty.63)$$

一如既往, $\tilde{H}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 上的波浪号强调, 它是仅在成对训练输入上求值的 $N_{\mathcal{A}} \times N_{\mathcal{A}}$ 维 NTK 均值子矩阵. 至此, 这一区别应当已经足够熟悉, 后文不再反复强调.

更重要的是, 这里使用完整 NTK 均值 $\tilde{H}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的逆, 而不是无限宽冻结 NTK $\tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$. 为解释原因, 回忆 (9.3): NTK 均值在 $1/n$ 展开的每一阶都会获得一系列修正, 其中领先阶部分是冻结 NTK (9.4). 既然现在工作到 $1/n$ 阶, 就尤其应当计入 NTK 均值的次领先阶 (NLO) $1/n$ 修正 $H_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{\{1\}}$, 也就是使用 $\tilde{H}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 而不是 $\tilde{\Theta}_{\tilde{\alpha}_1 \tilde{\alpha}_2}$.²⁴⁸

将无限宽巨大飞跃的 Newton 张量 (∞.62) 代入有限宽度下的巨大飞跃条件 (∞.61) 并整理, 得到

$$\begin{aligned} 0 = & \sum_{j, \tilde{\alpha}_1, \tilde{\alpha}_2} \widehat{\Delta H}_{ij; \tilde{\alpha} \tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j; \tilde{\alpha}_1} - y_{j; \tilde{\alpha}_1}) \\ & - \frac{1}{2} \sum_{\substack{j_1, j_2, \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_4}} \widehat{dH}_{ij_1 j_2; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\ & + \frac{1}{6} \sum_{\substack{j_1, j_2, j_3, \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_6}} \widehat{dd_1 H}_{ij_1 j_2 j_3; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_6} \\ & \times (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (\infty.64)$$

因此, 我们确实错过了最小值: 若网络已完全训练, 方程 (∞.64) 的右侧应当消失, 但这里它一般显然不为零. 退一步看, 现在很清楚, 在无限宽度下于 §10.2 真正得到的是

$$z_{i; \tilde{\alpha}}(t=1) - y_{i; \tilde{\alpha}} = O\left(\frac{1}{n}\right). \quad (\infty.65)$$

²⁴⁷对深网络而言, 严格说来修正应为 $O(L/n)$ 阶, 对应于有效理论描述的截断尺度.

²⁴⁸尽管不作显式推导, 我们预期这个 NLO NTK 均值 $H_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{\{1\}(\ell)}$ 相对于冻结 NTK 的解标度为 $O(1/n)$; 这类似于 NLO 度量 $G_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{\{1\}(\ell)}$ 的结果, 参见 §5.4 中 (5.143) 之后的讨论. 特别地, 如果像对初始化超参数在 (5.138) 和 (5.139) 中所做的那样, 对训练超参数 $\lambda_b^{(\ell)}$ 和 $\lambda_W^{(\ell)}$ 作 $1/n$ 展开, 那么次领先超参数 $\lambda_b^{(\ell)\{1\}}$ 和 $\lambda_W^{(\ell)\{1\}}$ 会提供额外自由度, 以消除 $H_{\tilde{\alpha}_1 \tilde{\alpha}_2}^{\{1\}(\ell)}$ 中随 ℓ 增长的贡献. 总体而言, 这将使 NTK 均值的 NLO 修正标度为 $O(1/n)$, 次领先于标度为 $O(L/n)$ 的领先有限宽度效应: 用 RG 流的语言说, NLO NTK 均值是边缘的. 在实践中, 这种贡献可以忽略, 因此对任何实际深度的网络都可以不计.

换言之，网络只在领先阶得到完全训练，而 (∞.64) 给出了 $1/n$ 修正的显式表达式。

进一步分解可知， $1/n$ 阶存在两类修正：第一类修正，即 (∞.64) 右侧第一项，来自不同初始化偏置与权重实现之间 NTK 的逐实现涨落；第二类修正，即 (∞.64) 右侧第二项与第三项，来自采取这一步时输出的非线性变化。特别地，第二类修正是有限宽度下表征学习的一种真正体现，它计入了网络有效特征的演化。若正确计入这两类 $1/n$ 修正，应当可以把训练误差降到 $1/n^2$ 阶：

$$z_{i;\tilde{\alpha}}(T) - y_{i;\tilde{\alpha}} = O\left(\frac{1}{n^2}\right). \quad (\infty.66)$$

也就是说，我们应当能够改进完全训练网络的有效理论：在定量上再乘上一个 $1/n$ 因子，在定性上则把表征学习恰当地纳入这种有效描述。

达到这种有效零训练误差 (∞.66) 的第一种方法 (§∞.2.1)，是继续设计理论上的巨大飞跃，以同时计入 NTK 的逐实现涨落以及 dNTK 和第一 ddNTK 的效应。

另一种方法 (§∞.2.2) 是像实践中那样，直接采用原始张量型梯度下降算法；此时不仅要计入网络输出的动力学，还要计入 NTK 和 dNTK 的动力学。完成这些工作后，将看到经过许许多多步迭代，训练损失可以降至零。

∞.2.1 巨大飞跃之后的一小步

这里将用两次二阶更新来训练网络。第一次更新是一次巨大飞跃；为恰当计入 NTK 的逐实现涨落，需要进一步推广理论优化算法。第二次更新是一小步；借助它可以计入非零 dNTK 与 ddNTK 所导致的 $1/n$ 阶表征变化，最终如 (∞.66) 那样落在损失最小值上。特别地，可以把这两次更新宽泛地理解为实践中用基于梯度的方法训练神经网络时出现的不同训练阶段。

第一次更新：梯度下降的最后一次推广

请翻回去仔细看看完全训练网络尚未满足的条件 (∞.64)。要满足这一约束，立即就会看到一个严重问题：NTK 涨落 $\widehat{\Delta H}_{ij;\tilde{\alpha}\tilde{\alpha}_1}$ 、dNTK $\widehat{dH}_{ij_1j_2;\tilde{\alpha}\tilde{\alpha}_1\tilde{\alpha}_2}$ 与 ddNTK $\widehat{dd_1H}_{ij_1j_2j_3;\tilde{\alpha}\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}$ 都会在一次更新中混合不同的输出分量；也就是说，初始化时预测误差 $z_{j;\tilde{\alpha}} - y_{j;\tilde{\alpha}}$ 的第 j 个分量会影响更新后输出 $z_{i;\tilde{\alpha}}$ 的第 i 个分量，即使 $i \neq j$ 也是如此。这与 §10.1.1 中无限宽更新的结果不同，那里不存在输出分量的这种混合或布线。另一方面，在 §6.4.2 深入讨论有限宽度下的贝叶斯推断时，我们确实见过类似的布线效应。

从实践者的角度看，有限宽度下的这种布线十分有益，但它会使理论工作略显复杂。特别地，为满足训练约束 (∞.64)，需要进一步推广二阶更新 (∞.57)。沿着此前两次推广 (7.11) 与 (10.18) 的思路，作最后一次推广：

$$\eta \rightarrow \eta \lambda_{\mu\nu} \rightarrow \eta \lambda_{\mu\nu} \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2} \rightarrow \eta \lambda_{\mu\nu} \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2}, \quad (\infty.67)$$

理论更新的最终形式为

$$d\theta_\mu = - \sum_{\nu, \tilde{\alpha}_1, \tilde{\alpha}_2, i, j} \eta \lambda_{\mu\nu} \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2} \frac{dz_{i;\tilde{\alpha}_1}}{d\theta_\nu} \epsilon_{j;\tilde{\alpha}_2}. \quad (\infty.68)$$

这里还引入了带输出分量指标的进一步广义 Newton 张量 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$. 这种自由度使我们能够消除无限宽飞跃后残余训练误差 (∞.64) 中输出分量的混合.²⁴⁹

要特别注意, $\lambda_{\mu\nu}$ 的 μ, ν 指标与 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的 i, j 指标截然不同: 前者各自遍历全部 P 个参数, 后者各自仅遍历网络输出的 n_L 个分量. 具体而言, 学习率张量 $\lambda_{\mu\nu}$ 控制第 ν 个参数的梯度如何影响第 μ 个参数的更新; 广义 Newton 张量 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的 i, j 指标则控制如何把网络的特征 (10.138) $dz_{i;\tilde{\alpha}_1}/d\theta_\nu$ 与误差因子 $\epsilon_{j;\tilde{\alpha}_2}$ 组合起来形成更新.²⁵⁰ 只要允许 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 在 i, j 指标上具有非零非对角分量, 就能精确调节一次特定更新中输出分量的布线或混合.

最后, 把最终形式的二阶更新 (∞.68) 代回网络更新的 $1/n$ 展开 (∞.4), 并使用 NTK、dNTK 与第一 ddNTK 的定义, 可得采用这一新优化算法作一次更新后网络输出的变化:

$$\begin{aligned} & z_{i;\delta}(t=1) \\ &= z_{i;\delta} - \eta \sum_{j,\tilde{\alpha}_1,\tilde{\alpha}_2} H_{\delta\tilde{\alpha}_1} \kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2}) - \eta \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{\Delta H}_{ij;\delta\tilde{\alpha}_1} \kappa_{jk}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{k;\tilde{\alpha}_2} - y_{k;\tilde{\alpha}_2}) \\ &+ \frac{\eta^2}{2} \sum_{\substack{j_1,j_2,k_1,k_2, \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4}} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2} \kappa_{j_1k_1}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \kappa_{j_2k_2}^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{k_1;\tilde{\alpha}_3} - y_{k_1;\tilde{\alpha}_3}) (z_{k_2;\tilde{\alpha}_4} - y_{k_2;\tilde{\alpha}_4}) \\ &- \frac{\eta^3}{6} \sum_{\substack{j_1,j_2,j_3,k_1,k_2,k_3 \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6}} \widehat{dd_1 H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \kappa_{j_1k_1}^{\tilde{\alpha}_1 \tilde{\alpha}_4} \kappa_{j_2k_2}^{\tilde{\alpha}_2 \tilde{\alpha}_5} \kappa_{j_3k_3}^{\tilde{\alpha}_3 \tilde{\alpha}_6} \\ &\quad \times (z_{k_1;\tilde{\alpha}_4} - y_{k_1;\tilde{\alpha}_4}) (z_{k_2;\tilde{\alpha}_5} - y_{k_2;\tilde{\alpha}_5}) (z_{k_3;\tilde{\alpha}_6} - y_{k_3;\tilde{\alpha}_6}) + O\left(\frac{1}{n^2}\right). \end{aligned} \tag{\infty.70}$$

这里再次使用标准 MSE 损失, 其误差因子由残余训练误差 $\epsilon_{j;\tilde{\alpha}} = z_{j;\tilde{\alpha}} - y_{j;\tilde{\alpha}}$ 给出. 接下来需要审慎选择广义 Newton 张量 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 以便第一次更新就能完全计入系综中特定网络的逐实现涨落.

²⁴⁹类似于 (10.22) 中的广义 MSE 损失 (见 §10.2.1), 也可以换一种方式理解这个进一步推广的二阶更新 (∞.68): 它对标准 MSE 损失的优化, 等价于标准一阶 (张量型) 梯度下降更新 (7.11) 对如下进一步推广的 MSE 损失的优化:

$$\mathcal{L}_{\mathcal{A},\kappa}(\theta) \equiv \frac{1}{2} \sum_{i_1,i_2=1}^{n_L} \sum_{\tilde{\alpha}_1,\tilde{\alpha}_2 \in \mathcal{A}} \kappa_{i_1 i_2}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{i_1;\tilde{\alpha}_1} - y_{i_1;\tilde{\alpha}_1}) (z_{i_2;\tilde{\alpha}_2} - y_{i_2;\tilde{\alpha}_2}), \tag{\infty.69}$$

前提是还假定 Newton 张量 $\kappa_{i_1 i_2}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 在成对指标交换 $(i_1, \tilde{\alpha}_1) \leftrightarrow (i_2, \tilde{\alpha}_2)$ 下对称. 实际上, 无论第一次更新的巨大飞跃, 还是第二次更新的一小步, 都具有这种对称性. 在 (∞.69) 的解释下, 广义 Newton 张量 $\kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 通过样本指标 $\tilde{\alpha}_1, \tilde{\alpha}_2$ 充当样本空间上的度量, 并通过第 L 层神经元指标 i, j 充当输出分量空间上的度量.

²⁵⁰在 §10.4 中把无限宽网络解释为线性模型时, 定义随机特征函数 $\hat{\phi}_{i,\mu}(x)$ 的 (10.138) 也对参数指标 μ 和输出分量指标 i 作过类似区分. 在 §11.4.3 中还讨论过如何把布线纳入表征学习的非极小模型.

受 $1/n$ 阶失效的无限宽 Newton 步 (∞.62) 启发, 作如下形式相近的第一步:

$$\begin{aligned} \eta \kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2} &= \left(\widehat{H}^{-1} \right)_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \\ &= \delta_{ij} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widehat{\Delta H}_{ij; \tilde{\alpha}_3 \tilde{\alpha}_4} \widetilde{H}^{\tilde{\alpha}_4 \tilde{\alpha}_2} \\ &\quad + \sum_{k=1}^{n_L} \sum_{\tilde{\alpha}_3, \dots, \tilde{\alpha}_6 \in \mathcal{A}} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widehat{\Delta H}_{ik; \tilde{\alpha}_3 \tilde{\alpha}_4} \widetilde{H}^{\tilde{\alpha}_4 \tilde{\alpha}_5} \widehat{\Delta H}_{kj; \tilde{\alpha}_5 \tilde{\alpha}_6} \widetilde{H}^{\tilde{\alpha}_6 \tilde{\alpha}_2} + O(\Delta^3). \end{aligned} \quad (\infty.71)$$

这里引入了在训练集上求值的随机 NTK 子张量的完整逆, 它满足

$$\sum_{j, \tilde{\alpha}_2} \left(\widehat{H}^{-1} \right)_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \widehat{H}_{jk; \tilde{\alpha}_2 \tilde{\alpha}_3} = \delta_{ik} \delta_{\tilde{\alpha}_1 \tilde{\alpha}_3}, \quad (\infty.72)$$

在 (∞.71) 最后一等式中使用了 Schwinger–Dyson 方程 (4.55); 用物理学家的话说, 就是围绕 NTK 均值展开随机 NTK 的逆.²⁵¹ 这个新巨大飞跃 (∞.71) 与此前无限宽巨大飞跃 (∞.62) 的主要区别是: 现在计入了模型参数不同实现之间 NTK 的逐实现涨落; 换言之, 对每个具有相应 NTK $\widehat{H}_{i_1 i_2; \tilde{\alpha}_1 \tilde{\alpha}_2}$ 的特定网络, 都实施一个不同的 Newton 步. 因而, 这一步可以宽泛地对应于该特定网络训练的第一阶段.

采取这一步, 即把广义 Newton 张量 (∞.71) 代入网络输出更新 (∞.70), 可得训练误差下降为

$$\begin{aligned} &z_{i; \tilde{\alpha}}(t=1) - y_{i; \tilde{\alpha}} \\ &= \frac{1}{2} \sum_{\substack{j_1, j_2, \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_4}} \widehat{dH}_{ij_1 j_2; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widetilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\ &\quad - \frac{1}{6} \sum_{\substack{j_1, j_2, j_3, \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_6}} \widehat{dd_1 H}_{ij_1 j_2 j_3; \tilde{\alpha} \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_4} \widetilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_5} \widetilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_6} \\ &\quad \times (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (\infty.73)$$

因此, 第一类 $1/n$ 修正已被正确处理; 这一步把训练集上的残余预测误差从初始预测的一阶误差

$$z_{i; \tilde{\alpha}}(t=0) - y_{i; \tilde{\alpha}} = O(1), \quad (\infty.74)$$

降到小得多的误差

$$z_{i; \tilde{\alpha}}(t=1) - y_{i; \tilde{\alpha}} = O\left(\frac{1}{n}\right), \quad (\infty.75)$$

它宽泛地对应于实践中训练网络时经验上观察到的初始误差大幅下降. 此外, (∞.73) 中剩余的误差现在完全来自 dNTK 与第一 ddNTK 所编码的额外有限宽度修正, 也就是表征学习的结果.²⁵²

²⁵¹ 尽管说过不再纠缠此事, 这里却不幸又必须决定给逆 $\left(\widehat{H}^{-1} \right)_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 戴帽子还是加波浪号; 我们选择了帽子. 希望样本指标上的波浪号 (例如 $\tilde{\alpha}_1, \tilde{\alpha}_2$) 能提醒你, 这个随机对象的逆只相对于训练集来取. 任何时候都不需要在一般数据集 $\mathcal{D}$ 上求值的随机 NTK 之逆.

²⁵² 特别地, 只有当 NTK 在梯度下降中保持常数时, 第一次更新 (∞.71) 才会满足训练条件 (∞.66). 这类现象实际上有一个名称: 惰性训练, 指网络函数的行为仿佛等于其参数初值附近的线性化 [70]. 根据 §10.4 的讨论, 若 NTK 为常数, 网络就是线性模型.

第二次更新：表征学习反击

为了进一步减小训练误差，需要再次更新网络，以进一步计入第一次更新时网络表征已经演化这一事实。换言之，需要作第二次梯度下降更新。如果愿意，可以把这次更新想象成对应于训练的第二阶段：在第一阶段中，网络利用初始化时求值的 NTK 显著减小了训练误差；现在，模型必须精炼其特征，以进一步改善性能。

相应地，由于训练误差已经降至 $\sim 1/n$ ，第二次更新将比第一次小得多。特别地，为精确抵消剩余的 $1/n$ 阶训练误差，更新本身必然只能是 $1/n$ 阶；也就是说，与其说它是又一次巨大飞跃，不如说它是一小步。²⁵³

为确定需要采取哪一步，把第二次更新后的网络输出写为

$$\begin{aligned} z_{i;\delta}(t=2) & \quad (\infty.76) \\ &= z_{i;\delta}(t=1) - \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} H_{ij;\delta\tilde{\alpha}_1}(t=1) \eta \kappa_{jk}^{\tilde{\alpha}_1\tilde{\alpha}_2}(t=1) [z_{k;\tilde{\alpha}_2}(t=1) - y_{k;\tilde{\alpha}_2}] + O\left(\frac{1}{n^2}\right) \\ &= z_{i;\delta}(t=1) - \sum_{j,\tilde{\alpha}_1,\tilde{\alpha}_2} H_{\delta\tilde{\alpha}_1} \eta \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2}(t=1) [z_{j;\tilde{\alpha}_2}(t=1) - y_{j;\tilde{\alpha}_2}] + O\left(\frac{1}{n^2}\right), \end{aligned}$$

这里暂时没有指定第二次更新中全局学习率与广义 Newton 张量的乘积 $\eta \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2}(t=1)$ 。注意，在第一个等式中略去了 $d(d)\text{NTK}$ 项：第一次更新 ([∞.73](#)) 后，训练误差已经降至 $O(1/n)$ ，所以原本可能出现的 $d\text{NTK}$ 项极其次领先， $\sim \widehat{dH} \times [\epsilon(t=1)]^2 = O(1/n^3)$ ；原本可能出现的 $dd\text{NTK}$ 项则低得近乎荒谬， $\sim \widehat{dd_1H} \times [\epsilon(t=1)]^3 = O(1/n^4)$ 。类似地，在第三行中，把第一步之后的 NTK $H_{ij;\delta\tilde{\alpha}_1}(t=1)$ 替换成了初始化时的 NTK 均值 $\delta_{ij}H_{\delta\tilde{\alpha}_1}$ 。鉴于第一步之后训练误差受到 $1/n$ 抑制，这一替换可由以下两个理由共同论证：*(i)* NTK 的更新 $H_{ij;\delta\tilde{\alpha}}(t=1) - H_{ij;\delta\tilde{\alpha}}(t=0)$ 本身受到 $1/n$ 抑制，参见 ([∞.6](#))，因此可以使用更新前的版本；*(ii)* 相较于均值，NTK 涨落也受到抑制，因而可以进一步把初始化时的随机 NTK 换成其均值。这意味着，只要为第二次小步更新作如下选择：

$$\eta \kappa_{ij}^{\tilde{\alpha}_1\tilde{\alpha}_2}(t=1) = \delta_{ij} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} + O\left(\frac{1}{n}\right), \quad (\infty.77)$$

那么由 ([∞.76](#)) 很容易看出，网络现在将如 ([∞.66](#)) 那样得到完全训练：

$$z_{i;\tilde{\alpha}}(t=2) - y_{i;\tilde{\alpha}} = O\left(\frac{1}{n^2}\right). \quad (\infty.78)$$

因此，与第一次更新后的误差 ([∞.73](#)) 相比，第二次更新又把残余训练误差减小了一个 $1/n$ 因子。²⁵⁴

²⁵³如下文所示，两次更新的整体学习率本质上相同；第二次更新更小，仅仅是因为第一次更新之后，损失梯度在最小值附近本身已经小得多。

²⁵⁴这表明，继续更新或许能不断以额外的 $1/n$ 因子减小训练误差。不过，这些由有效理论描述的高阶修正决定的进一步精炼，在定性上将与 $O(L/n)$ 阶领先有限宽度描述相同。换言之，把无限宽描述改进为有限宽描述会纳入表征学习，而更精确的有限宽描述只会让模型进一步精炼其特征。在实践中，对于纵横比 L/n 取合理值的网络，我们预期领先有限宽度描述已经非常准确。

对于一般输入 $\delta \in \mathcal{D}$, 把学习率与 Newton 张量的选择 (∞.77) 代回第二次更新 (∞.76), 并进一步用带 (∞.71) 的 (∞.70) 重新表示第一步之后的网络输出 $z_{i;\delta}(t=1)$, 得到

$$\begin{aligned}
 & z_{i;\delta}(t=2) \\
 = & z_{i;\delta} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} H_{\delta \tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{i;\tilde{\alpha}_2} - y_{i;\tilde{\alpha}_2}) \\
 & + \sum_{j=1}^{n_L} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2 \in \mathcal{A}} \left[\widehat{\Delta H}_{ij;\delta \tilde{\alpha}_1} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} H_{\delta \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_4} \widehat{\Delta H}_{ij;\tilde{\alpha}_4 \tilde{\alpha}_1} \right] \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2}) \\
 & - \sum_{j,k=1}^{n_L} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \left[\widehat{\Delta H}_{ij;\delta \tilde{\alpha}_1} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6 \in \mathcal{A}} H_{\delta \tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \widehat{\Delta H}_{ij;\tilde{\alpha}_6 \tilde{\alpha}_1} \right] \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \widehat{\Delta H}_{jk;\tilde{\alpha}_2 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_4} (z_{k;\tilde{\alpha}_4} - y_{k;\tilde{\alpha}_4}) \\
 & + \frac{1}{2} \sum_{j_1, j_2=1}^{n_L} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4 \in \mathcal{A}} \left[\widehat{\mathrm{d}H}_{ij_1 j_2; \delta \tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6 \in \mathcal{A}} H_{\delta \tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \widehat{\mathrm{d}H}_{ij_1 j_2; \tilde{\alpha}_6 \tilde{\alpha}_1 \tilde{\alpha}_2} \right] \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\
 & - \frac{1}{6} \sum_{j_1, j_2, j_3=1}^{n_L} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_6 \in \mathcal{A}} \left[\widehat{\mathrm{dd}H}_{ij_1 j_2 j_3; \delta \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7, \tilde{\alpha}_8 \in \mathcal{A}} H_{\delta \tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_7 \tilde{\alpha}_8} \widehat{\mathrm{dd}H}_{ij_1 j_2 j_3; \tilde{\alpha}_8 \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \right] \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & + O\left(\frac{1}{n^2}\right).
 \end{aligned} \tag{\infty.79}$$

这里可以看到, 对所有训练输入 $\delta = \tilde{\alpha} \in \mathcal{A}$, 方括号内的表达式恒等地消失; 因此网络得到了完全训练. 特别地, 由于 (∞.79) 右侧所有变量都取在初始化时, 这个解实现了目标 (∞.55): 把完全训练网络的输出表示为这些初始化变量的泛函. 相应地, 现在可以从初始化时预激活量-NTK-dNTK-ddNTK 的联合分布 (∞.53), 求出完全训练分布 (∞.56) 的统计量.²⁵⁵

²⁵⁵也可以只用一次更新得到同一个解: 选择如下广义 Newton 张量, 作一次精细调谐的巨大飞跃:

$$\begin{aligned}
 \eta \kappa_{ij}^{\tilde{\alpha}_1 \tilde{\alpha}_2} = & \delta_{ij} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widehat{\Delta H}_{ij;\tilde{\alpha}_3 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_4 \tilde{\alpha}_2} \\
 & + \sum_{k=1}^{n_L} \sum_{\tilde{\alpha}_3, \dots, \tilde{\alpha}_6 \in \mathcal{A}} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widehat{\Delta H}_{ik;\tilde{\alpha}_3 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_4 \tilde{\alpha}_5} \widehat{\Delta H}_{kj;\tilde{\alpha}_5 \tilde{\alpha}_6} \tilde{H}^{\tilde{\alpha}_6 \tilde{\alpha}_2} \\
 & + \frac{1}{2} \sum_{k=1}^{n_L} \sum_{\tilde{\alpha}_3, \dots, \tilde{\alpha}_6 \in \mathcal{A}} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_5 \tilde{\alpha}_6} \widehat{\mathrm{d}H}_{ijk;\tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5} (z_{k;\tilde{\alpha}_6} - y_{k;\tilde{\alpha}_6}) \\
 & - \frac{1}{6} \sum_{k_1, k_2=1}^{n_L} \sum_{\tilde{\alpha}_3, \dots, \tilde{\alpha}_8 \in \mathcal{A}} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_5 \tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_6 \tilde{\alpha}_8} \widehat{\mathrm{dd}H}_{ijk_1 k_2; \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \\
 & \quad \times (z_{k_1; \tilde{\alpha}_7} - y_{k_1; \tilde{\alpha}_7}) (z_{k_2; \tilde{\alpha}_8} - y_{k_2; \tilde{\alpha}_8}).
 \end{aligned} \tag{\infty.80}$$

本质上, (∞.80) 的前三项来自随机 NTK 求逆, 对应于第一次更新的巨大飞跃 (∞.71), 并计入 NTK 的逐实现涨落. 与之相反, 最后两项对应于第二次更新的一小步 (∞.78), 计入由 dNTK-ddNTK 引起的表

尽管这些结果十分振奋，仍要提醒读者：这些广义二阶更新或许最好仅被视为训练算法的简单理论模型，其设计目的是让我们能够解析地理解训练过程；我们绝不是在暗示它们是实践优化中的良好或实用选项。相反，最实用的优化算法是原始一阶梯度下降。前文已经指出，完全训练网络的输出确实依赖于优化算法的细节，因此现在别无选择，只能显式分析梯度下降的许许多多步。

∞.2.2 梯度下降的许许多多步

在这个较长的小节中，我们将研究张量型梯度下降 (7.11)，并使用恒定的全局学习率 η ，按照 MSE 损失优化有限宽度神经网络。²⁵⁶ 采用这种所有其他基于梯度的学习方法之先祖算法，网络输出将依照 (∞.4) 演化为

$$\begin{aligned} z_{i;\delta}(t+1) = & z_{i;\delta}(t) - \eta \sum_{j,\tilde{\alpha}} H_{ij;\delta\tilde{\alpha}}(t) [z_{j;\tilde{\alpha}}(t) - y_{j;\tilde{\alpha}}] \\ & + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} dH_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}(t) [z_{j_1;\tilde{\alpha}_1}(t) - y_{j_1;\tilde{\alpha}_1}] [z_{j_2;\tilde{\alpha}_2}(t) - y_{j_2;\tilde{\alpha}_2}] \\ & - \frac{\eta^3}{6} \sum_{j_1,j_2,j_3,\tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3} \widehat{dd_1 H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \\ & \times [z_{j_1;\tilde{\alpha}_1}(t) - y_{j_1;\tilde{\alpha}_1}] [z_{j_2;\tilde{\alpha}_2}(t) - y_{j_2;\tilde{\alpha}_2}] [z_{j_3;\tilde{\alpha}_3}(t) - y_{j_3;\tilde{\alpha}_3}] , \end{aligned} \quad (\infty.81)$$

与此同时，NTK 将依照 (∞.6) 演化为

$$\begin{aligned} H_{i_1i_2;\delta_1\delta_2}(t+1) & = H_{i_1i_2;\delta_1\delta_2}(t) - \eta \sum_{j,\tilde{\alpha}} \left(dH_{i_1i_2j;\delta_1\delta_2\tilde{\alpha}}(t) + dH_{i_2i_1j;\delta_2\delta_1\tilde{\alpha}}(t) \right) [z_{j;\tilde{\alpha}}(t) - y_{j;\tilde{\alpha}}] \\ & + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \left(\widehat{dd_1 H}_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2} + \widehat{dd_1 H}_{i_2i_1j_1j_2;\delta_2\delta_1\tilde{\alpha}_1\tilde{\alpha}_2} + 2\widehat{dd_{II} H}_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2} \right) \\ & \times [z_{j_1;\tilde{\alpha}_1}(t) - y_{j_1;\tilde{\alpha}_1}] [z_{j_2;\tilde{\alpha}_2}(t) - y_{j_2;\tilde{\alpha}_2}] , \end{aligned} \quad (\infty.82)$$

征学习。注意，由于最后一项，这个广义 Newton 张量 (∞.80) 在成对指标交换 $(i, \tilde{\alpha}_1) \leftrightarrow (j, \tilde{\alpha}_2)$ 下不对称，所以这个精细调谐的更新无法再解释为用进一步推广的损失 (∞.69) 进行优化。

这次单步更新类似于 §11.4 中二次回归的直接优化解 (11.132)。这个单步算法 (∞.80) 的精细调谐程度表明：采取许多次简单步骤，比采取较少但复杂的步骤更容易作出抵达解所需的精细调整。接下来在 §∞.2.2 研究原始梯度下降的许许多多步时，将看到这一点的另一面。

²⁵⁶不要被张量型一词吓到；这仅仅意味着，允许把训练超参数 $\lambda_b^{(\ell)}$ 与 $\lambda_W^{(\ell)}$ 纳入 NTK 的定义。为什么纳入这些超参数是个好主意，现在应当已经很清楚；若仍不清楚，请翻回 §9.4，重读关于学习率等价原理的段落。在实践中，把它们纳入任何优化算法其实也很简单。

此外，由于它们只是 NTK 定义的一部分，对这里给出的动力学没有任何影响；也就是说，我们的解同样涵盖非张量型梯度下降，只是在这种情形下，NTK、dNTK 与 ddNTK 统计量的渐近解会有所不同。这也是为什么我们认为训练超参数 $\lambda_b^{(\ell)}$ 与 $\lambda_W^{(\ell)}$ 独立于优化算法本身的细节。

并且, dNTK 还将依照 (∞.9) 演化为

$$\begin{aligned} & dH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}(t+1) \\ &= dH_{i_0 i_1 i_2; \delta_0 \delta_1 \delta_2}(t) \\ & \quad - \eta \sum_{j, \tilde{\alpha}} \left(\widehat{dd_I H}_{i_0 i_1 i_2 j; \delta_0 \delta_1 \delta_2 \tilde{\alpha}} + \widehat{dd_{II} H}_{i_0 i_1 i_2 j; \delta_0 \delta_1 \delta_2 \tilde{\alpha}} + \widehat{dd_{III} H}_{i_0 i_2 i_1 j; \delta_0 \delta_2 \delta_1 \tilde{\alpha}} \right) [z_{j; \tilde{\alpha}}(t) - y_{j; \tilde{\alpha}}] . \end{aligned} \quad (\infty.83)$$

写下这些动力学方程时, 我们不再显式标记方程具有 $O(1/n^2)$ 误差; 同时还表达了这样一个事实: ddNTK 在 $1/n$ 阶与步数 t 无关, 因而使用它们在初始化时的值 $\widehat{dd_I H}_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}$ 与 $\widehat{dd_{II} H}_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}$, 并用帽子提醒我们它们具有随机性. 联合更新 (∞.81)、(∞.82) 与 (∞.83) 是耦合的差分方程, 而且网络输出和动力学 NTK 的方程关于输出 $z_{i; \delta}$ 都是非线性的.

尽管这看起来令人生畏, 我们现在却要以闭式求解这些方程. 首先, 忽略 dNTK 与 ddNTK 的有限宽度效应来分析动力学, 此时问题将化为单个线性差分方程. 随后使用微扰理论纳入所有 NTK 微分的效应, 从而允许 NTK 与 dNTK 动态演化.

自由理论: 与步数无关的 NTK

首先把 dNTK 与 ddNTK 设为零. 由于它们的领先统计量受到 $1/n$ 抑制, 稍后可以利用微扰理论重新纳入它们的全部效应. 在这一极限下, NTK 更新方程 (∞.82) 是平凡的, 其解为自由或与步数无关的 NTK:

$$H_{i_1 i_2; \delta_1 \delta_2}(t) = H_{i_1 i_2; \delta_1 \delta_2}(t=0) \equiv \hat{H}_{i_1 i_2; \delta_1 \delta_2} . \quad (\infty.84)$$

毫不意外, 这只意味着当 dNTK 与 ddNTK 消失时, NTK 不会偏离其初始化值而发生更新.

把这个解代入预激活量更新方程 (∞.81), 并关闭 dNTK 与 ddNTK, 剩余的动力学方程简化为

$$z_{i; \delta}(t+1) = z_{i; \delta}(t) - \eta \sum_{j, \tilde{\alpha}} \hat{H}_{ij; \delta \tilde{\alpha}} [z_{j; \tilde{\alpha}}(t) - y_{j; \tilde{\alpha}}] . \quad (\infty.85)$$

因此, 残余训练误差 $z_{\tilde{\alpha}}(t) - y_{\tilde{\alpha}}$ 驱动一般输入 $\delta \in \mathcal{D}$ 上网络输出 $z_{\delta}(t)$ 的更新. 此外, 把输入限制在训练集 $\tilde{\alpha} \in \mathcal{A}$ 上, 就能把这个差分方程 (∞.85) 重写为

$$z_{i; \tilde{\alpha}}(t+1) - y_{i; \tilde{\alpha}} = \sum_{j, \tilde{\alpha}_1} \left(I_{ij; \tilde{\alpha} \tilde{\alpha}_1} - \eta \hat{H}_{ij; \tilde{\alpha} \tilde{\alpha}_1} \right) [z_{j; \tilde{\alpha}_1}(t) - y_{j; \tilde{\alpha}_1}] , \quad (\infty.86)$$

这里定义了恒等算子

$$I_{i_1 i_2; \tilde{\alpha}_1 \tilde{\alpha}_2} \equiv \delta_{i_1 i_2} \delta_{\tilde{\alpha}_1 \tilde{\alpha}_2} . \quad (\infty.87)$$

在这种形式下, (∞.86) 是残余训练误差 $z_{\tilde{\alpha}}(t) - y_{\tilde{\alpha}}$ 的一阶齐次线性差分方程; 说得花哨一些, 就是这个问题将会易如反掌.

特别地, 预测误差的更新只是简单地乘以一个常矩阵, 其解由指数给出:

$$z_{i; \tilde{\alpha}}^F(t) - y_{i; \tilde{\alpha}} = \sum_{j, \tilde{\alpha}_1} U_{ij; \tilde{\alpha} \tilde{\alpha}_1}(t) (z_{j; \tilde{\alpha}_1} - y_{j; \tilde{\alpha}_1}) . \quad (\infty.88)$$

左侧用 F 标记这个解，表示它是关闭 dNTK 与 ddNTK 非线性效应后的自由解；右侧是初始化时的残余训练误差，而**步演化算子**定义为 t 步的迭代乘积：

$$\begin{aligned} U_{i_t i_0; \tilde{\alpha}_t \tilde{\alpha}_0}(t) &\equiv \left[\left(I - \eta \hat{H} \right)^t \right]_{i_t i_0; \tilde{\alpha}_t \tilde{\alpha}_0} \\ &= \sum_{\substack{i_1, \dots, i_{t-1} \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_{t-1}}} \left(I_{i_t i_{t-1}; \tilde{\alpha}_t \tilde{\alpha}_{t-1}} - \eta \hat{H}_{i_t i_{t-1}; \tilde{\alpha}_t \tilde{\alpha}_{t-1}} \right) \cdots \left(I_{i_1 i_0; \tilde{\alpha}_1 \tilde{\alpha}_0} - \eta \hat{H}_{i_1 i_0; \tilde{\alpha}_1 \tilde{\alpha}_0} \right). \end{aligned} \quad (\infty.89)$$

对于任意正定 NTK 和充分小的全局学习率 η ，当步数变大，即 $t \rightarrow \infty$ 时，这个算子将指数衰减至零， $U(t) \rightarrow 0$.²⁵⁷ 所以，残余训练误差 (∞.88) 将指数快速地消失：

$$\lim_{t \rightarrow \infty} z_{i; \tilde{\alpha}}^F(t) = y_{i; \tilde{\alpha}}, \quad (\infty.90)$$

各分量衰减的步数尺度由与步数无关的 NTK 决定.²⁵⁸

既然已经求解训练集上的自由动力学，就可以把解 (∞.88) 代回一般输入 $\delta \in \mathcal{D}$ 的差分方程 (∞.85). 驱动项已显式已知，所以很容易写出满足初始条件 $z_{i; \delta}^F(t=0) = z_{i; \delta}$ 的解：

$$\begin{aligned} z_{i; \delta}^F(t) &= z_{i; \delta} - \sum_{j, \tilde{\alpha}} \hat{H}_{ij; \delta \tilde{\alpha}} \left\{ \eta \sum_{s=0}^{t-1} [z_{j; \tilde{\alpha}}^F(s) - y_{j; \tilde{\alpha}}] \right\} \\ &= z_{i; \delta} - \sum_{j, \tilde{\alpha}_1, \tilde{\alpha}_2} \hat{H}_{ij; \delta \tilde{\alpha}_1} a_{j; \tilde{\alpha}}(t). \end{aligned} \quad (\infty.91)$$

这里定义了一个动力学辅助函数，其显式表示为

$$\begin{aligned} a_{j; \tilde{\alpha}}(t) &\equiv \eta \sum_{s=0}^{t-1} [z_{j; \tilde{\alpha}}^F(s) - y_{j; \tilde{\alpha}}] = \eta \sum_{s=0}^{t-1} \left[\sum_{k, \tilde{\alpha}_1} U_{jk; \tilde{\alpha} \tilde{\alpha}_1}(s) (z_{k; \tilde{\alpha}_1} - y_{k; \tilde{\alpha}_1}) \right] \\ &= \eta \sum_{k, \tilde{\alpha}_1} \left\{ \sum_{s=0}^{t-1} \left[\left(I - \eta \hat{H} \right)^s \right]_{jk; \tilde{\alpha} \tilde{\alpha}_1} \right\} (z_{k; \tilde{\alpha}_1} - y_{k; \tilde{\alpha}_1}) \\ &= \eta \sum_{k, m, \tilde{\alpha}_1, \tilde{\alpha}_2} \left\{ \left[I - \left(I - \eta \hat{H} \right) \right]^{-1} \right\}_{jm}^{\tilde{\alpha} \tilde{\alpha}_2} \left[I - \left(I - \eta \hat{H} \right) \right]_{mk; \tilde{\alpha}_2 \tilde{\alpha}_1}^t (z_{k; \tilde{\alpha}_1} - y_{k; \tilde{\alpha}_1}) \\ &= \sum_{m, \tilde{\alpha}_2} \left(\hat{H}^{-1} \right)_{jm}^{\tilde{\alpha} \tilde{\alpha}_2} \left\{ z_{m; \tilde{\alpha}_2} - y_{m; \tilde{\alpha}_2} - [z_{m; \tilde{\alpha}_2}^F(t) - y_{m; \tilde{\alpha}_2}] \right\}. \end{aligned} \quad (\infty.92)$$

²⁵⁷具体而言，要使这一极限收敛，只需 $\|I - \eta \hat{H}\|_\infty < 1$ ，即算子 $I - \eta \hat{H}$ 的最大特征值必须小于1。由于我们始终关注临界性原理与等价原理，初始化超参数与训练超参数的选择使 NTK 始终为一阶量，因此网络很容易满足这一约束。

²⁵⁸若想研究动力学的 ODE 或连续极限，可以令全局学习率趋于零， $\eta \rightarrow 0$ ，同时保持乘积 $\tau \equiv \eta t$ 固定。在这一极限下，步演化算子简单地变为 $U(t) \rightarrow \exp(-\hat{H}\tau)$ 。对任何理论目的而言，这个极限大多并无必要——直接研究真正描述实际优化算法的离散动力学同样容易——但它确实为 §7.2 的脚注 132 中反对把随机算子 $\hat{H}$ 称作神经正切核的意见提供了更多依据。特别地，这个连续极限清楚表明，最好把 NTK 真正看成一个 *Hamilton* 算子：它生成可观测量的演化，而步演化算子 $U(t)$ 则类似于么正时间演化算子，只不过时间是虚时间。更准确地说，在 dNTK 与 ddNTK 均设为零的极限下，NTK 类似于具有精确可解动力学的自由 Hamilton 算子；当 dNTK 或 ddNTK 非零时，Hamilton 算子包含非平凡的相互作用，可用含时微扰理论分析。

在这个表达式中, 从第二行得到第三行时使用了几何级数求和的标准公式 $1 + x + x^2 + \dots + x^{t-1} = (1 - x^t)/(1 - x)$; 得到最后一行时, 则计算了逆并代入步演化算子 (∞.89). 还要回忆, 由 (∞.72) 定义的 $\hat{H}^{-1}$ 是特定参数实现在训练集上求值的随机 NTK 子矩阵之逆.²⁵⁹

特别地, 对于充分小的 η , 当步数变大, 即 $t \rightarrow \infty$ 时, 残余误差 $z_{m;\tilde{\alpha}_2}^F(t) - y_{m;\tilde{\alpha}_2}$ 依照 (∞.90) 指数消失. 因此, 一般输入 $\delta \in \mathcal{D}$ 的预测 (∞.91) 将指数收敛到

$$z_{i;\delta}^F(t = \infty) = z_{i;\delta} - \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} \hat{H}_{ij;\delta\tilde{\alpha}_1} \left(\hat{H}^{-1} \right)_{jk}^{\tilde{\alpha}_1\tilde{\alpha}_2} (z_{k;\tilde{\alpha}_2} - y_{k;\tilde{\alpha}_2}). \quad (\infty.93)$$

尽管这里取了步数很大的极限, 但指数收敛意味着, 对任何满足 $T \gtrsim (\eta\hat{H})^{-1}$ 的步数 T , 预测误差都将指数接近其最终的 $T \rightarrow \infty$ 值.

事实上, 只要关闭 dNTK 与 ddNTK, 这个解 (∞.93) 就与 §∞.2.1 中第一次更新 (∞.68) 配合 Newton 张量 (∞.71) 所得的解精确一致. 这意味着, 有限宽度下涌现的算法依赖性完全源于 NTK 微分存在以及由此产生的非线性动力学.

相互作用理论: 动力学 NTK 与 dNTK

现在把非零 dNTK 与 ddNTK 纳入分析. 为此, 需要把动力学网络输出与动力学 NTK 分解为

$$z_{i;\delta}(t) \equiv z_{i;\delta}^F(t) + z_{i;\delta}^I(t), \quad (\infty.94)$$

$$H_{ij;\delta\tilde{\alpha}}(t) \equiv \hat{H}_{ij;\delta\tilde{\alpha}} + H_{ij;\delta\tilde{\alpha}}^I(t). \quad (\infty.95)$$

对网络输出而言, $z_{i;\delta}^F(t)$ 是自由部分, 它满足线性差分方程 (∞.85), 其解由 (∞.91) 给出; $z_{i;\delta}^I(t)$ 是相互作用部分, 囊括所有非零 NTK 微分带来的修正. 类似地, 对 NTK 而言, $\hat{H}_{ij;\delta\tilde{\alpha}}$ 是在初始化时固定、与步数无关的自由部分, 而 $H_{ij;\delta\tilde{\alpha}}^I(t)$ 是动态且依赖步数的相互作用 NTK.

由于在自由极限 $\widehat{dH}, \widehat{dd_I H}, \widehat{dd_{II} H} \rightarrow 0$ 下, $z_{i;\delta}^I(t)$ 与 $H_{ij;\delta\tilde{\alpha}}^I(t)$ 都不存在, 因此在领先阶预期它们是这些对象的线性组合, 示意地写为

$$z^I(t) = [\text{thing } 0](t) \widehat{dH} + [\text{thing } 1](t) \widehat{dd_I H} + [\text{thing } 2](t) \widehat{dd_{II} H}, \quad (\infty.96)$$

$$H^I(t) = [\text{thing } 0](t) \widehat{dH} + [\text{thing } 1](t) \widehat{dd_I H} + [\text{thing } 2](t) \widehat{dd_{II} H}, \quad (\infty.97)$$

其中不同的张量型对象具有不同的时间依赖性. 这又意味着, 在领先阶可以忽略 $z_{i;\delta}^I(t)$ 或 $H_{ij;\delta\tilde{\alpha}}^I(t)$ 与 $\widehat{dH}, \widehat{dd_I H}, \widehat{dd_{II} H}$ 中任一对象的乘积; 这正是我们能够用微扰理论系统求解这些非线性动力学的主要原因. 最后, 网络输出与 NTK 的相互作用部分必须满足初始条件

$$z_{i;\delta}^I(t = 0) = 0, \quad (\infty.98)$$

$$H_{ij;\delta\tilde{\alpha}}^I(t = 0) = 0, \quad (\infty.99)$$

²⁵⁹遗憾的是, 在没有 Newton 张量的情况下, (∞.92) 中升降位置不同的样本指标无法很好地对齐. 事实上, 问题真正始于更新方程 (∞.85) 中重复降低的 $\tilde{\alpha}$ 指标. 如果愿意, 可以审慎使用 $\delta_{\tilde{\alpha}_1\tilde{\alpha}_2}$ 与 $\delta^{\tilde{\alpha}_3\tilde{\alpha}_4}$ 等恒等矩阵来修复它. 不过, 尽管这种指标对齐可以带来额外的清晰性和类型安全, 如此使用恒等矩阵会让表述过分杂乱, 因而大概并不值得.

因为网络输出的自由部分已经在初始化时满足 $z_{i;\delta}^F(t=0) = z_{i;\delta}$, 而 NTK 的自由部分与步数无关, 因此就是初始化时的 NTK.

考虑到这些事实, 现在的目标是求出 $z_{i;\delta}^I(t)$, 使完整网络输出 $z_{i;\delta}(t)$ 、相互作用 NTK $H_{ij;\delta\tilde{\alpha}}^I(t)$ 以及动力学 dNTK $dH_{i_0i_1i_2;\delta_0\delta_1\delta_2}(t)$ 共同在 $1/n$ 领先阶满足耦合非线性动力学 (∞.81)、(∞.82) 与 (∞.83).

首先求解 dNTK 的动力学. 由 (∞.83) 可见, dNTK 的更新由残余训练误差 $z_{i;\tilde{\alpha}}(t) - y_{i;\tilde{\alpha}}$ 驱动. 使用网络输出的分解 (∞.94) 和初始条件

$$dH_{i_0i_1i_2;\delta_0\delta_1\delta_2}(t=0) = \widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2}, \quad (\infty.100)$$

迭代动力学之后得到

$$\begin{aligned} & dH_{i_0i_1i_2;\delta_0\delta_1\delta_2}(t) \\ &= \widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2} - \sum_{j,\tilde{\alpha}} \left(\widehat{dd_I}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}} + \widehat{dd_{II}}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}} + \widehat{dd_{III}}H_{i_0i_2i_1j;\delta_0\delta_2\delta_1\tilde{\alpha}} \right) \\ & \quad \times \left\{ \eta \sum_{s=0}^{t-1} [z_{j;\tilde{\alpha}}^F(s) + z_{j;\tilde{\alpha}}^I(s) - y_{j;\tilde{\alpha}}] \right\} \\ &= \widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2} - \sum_{j,\tilde{\alpha}} \left(\widehat{dd_I}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}} + \widehat{dd_{II}}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}} + \widehat{dd_{III}}H_{i_0i_2i_1j;\delta_0\delta_2\delta_1\tilde{\alpha}} \right) a_{j;\tilde{\alpha}}(t). \end{aligned} \quad (\infty.101)$$

最后一步先按照前面的说明, 略去 $z_{i;\delta}^I(t)$ 与 $\widehat{dd_I}H$ 的乘积, 然后代入动力学辅助函数 (∞.92). 现在代入 (∞.92) 的最终表达式, 并把 NTK 逆的涨落部分作为次领先项忽略, 就得到动力学 dNTK 的表达式:

$$\begin{aligned} & \widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2}(t) \\ &= \widehat{dH}_{i_0i_1i_2;\delta_0\delta_1\delta_2} - \sum_{k,\tilde{\alpha}_1,\tilde{\alpha}_2} \left(\widehat{dd_I}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}_1} + \widehat{dd_{II}}H_{i_0i_1i_2j;\delta_0\delta_1\delta_2\tilde{\alpha}_1} + \widehat{dd_{III}}H_{i_0i_2i_1j;\delta_0\delta_2\delta_1\tilde{\alpha}_1} \right) \\ & \quad \times \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} \{ z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2} - [z_{j;\tilde{\alpha}_2}^F(t) - y_{j;\tilde{\alpha}_2}] \}. \end{aligned} \quad (\infty.102)$$

特别地, 花括号内的量表示初始化与第 t 步之间训练误差的差: 这个差越大, 也就是残余训练误差下降得越多, dNTK 的演化就越大, 元特征函数也演化得越多, 并在训练过程中经历自身形式的元表征学习. 接下来, 利用网络输出与 NTK 的分解 (∞.94) 和 (∞.95), 可以把 NTK 动力学 (∞.82) 改写成关于相互作用 NTK 的差分方程:

$$\begin{aligned} & H_{i_1i_2;\delta_1\delta_2}^I(t+1) \\ &= H_{i_1i_2;\delta_1\delta_2}^I(t) - \eta \sum_{j,\tilde{\alpha}} \left(dH_{i_1i_2j;\delta_1\delta_2\tilde{\alpha}}(t) + dH_{i_2i_1j;\delta_2\delta_1\tilde{\alpha}}(t) \right) [z_{j;\tilde{\alpha}}^F(t) - y_{j;\tilde{\alpha}}] \\ & \quad + \frac{\eta^2}{2} \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2} \left(\widehat{dd_I}H_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2} + \widehat{dd_{II}}H_{i_2i_1j_1j_2;\delta_2\delta_1\tilde{\alpha}_1\tilde{\alpha}_2} + 2\widehat{dd_{III}}H_{i_1i_2j_1j_2;\delta_1\delta_2\tilde{\alpha}_1\tilde{\alpha}_2} \right) \\ & \quad \times [z_{j_1;\tilde{\alpha}_1}^F(t) - y_{j_1;\tilde{\alpha}_1}] [z_{j_2;\tilde{\alpha}_2}^F(t) - y_{j_2;\tilde{\alpha}_2}]. \end{aligned} \quad (\infty.103)$$

这里再次略去了右端网络输出的相互作用部分, 因为它总要乘以 dNTK 或 ddNTK, 因而在 $1/n$ 下是次领先的. 为了简化记号, 把自由部分的残余训练误差 (∞.88) 记为

$$\epsilon_{j;\tilde{\alpha}}^F(t) \equiv z_{j;\tilde{\alpha}}^F(t) - y_{j;\tilde{\alpha}}, \quad (\infty.104)$$

再代入动力学 dNTK 的解 (∞.102), 便得到

$$\begin{aligned}
 & H_{i_1 i_2; \delta_1 \delta_2}^I(t+1) - H_{i_1 i_2; \delta_1 \delta_2}^I(t) \\
 &= -\eta \sum_{j, \tilde{\alpha}} \left(\widehat{dH}_{i_1 i_2 j; \delta_1 \delta_2 \tilde{\alpha}} + \widehat{dH}_{i_2 i_1 j; \delta_2 \delta_1 \tilde{\alpha}} \right) \epsilon_{j; \tilde{\alpha}}^F(t) \\
 &+ \eta \sum_{j, k, \tilde{\alpha}, \tilde{\alpha}_1, \tilde{\alpha}_2} \left(\widehat{dd_I H}_{i_1 i_2 j k; \delta_1 \delta_2 \tilde{\alpha} \tilde{\alpha}_1} + \widehat{dd_{II} H}_{i_1 i_2 j k; \delta_1 \delta_2 \tilde{\alpha} \tilde{\alpha}_1} + \widehat{dd_{II} H}_{i_1 j i_2 k; \delta_1 \tilde{\alpha} \delta_2 \tilde{\alpha}_1} \right. \\
 &\quad \left. + \widehat{dd_I H}_{i_2 i_1 j k; \delta_2 \delta_1 \tilde{\alpha} \tilde{\alpha}_1} + \widehat{dd_{II} H}_{i_2 i_1 j k; \delta_2 \delta_1 \tilde{\alpha} \tilde{\alpha}_1} + \widehat{dd_{II} H}_{i_2 j i_1 k; \delta_2 \tilde{\alpha} \delta_1 \tilde{\alpha}_1} \right) \\
 &\quad \times \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \epsilon_{j; \tilde{\alpha}}^F(t) [z_{k; \tilde{\alpha}_2} - y_{k; \tilde{\alpha}_2} - \epsilon_{k; \tilde{\alpha}_2}^F(t)] \\
 &+ \frac{\eta^2}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} \left(\widehat{dd_I H}_{i_1 i_2 j_1 j_2; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_I H}_{i_2 i_1 j_1 j_2; \delta_2 \delta_1 \tilde{\alpha}_1 \tilde{\alpha}_2} + 2\widehat{dd_{II} H}_{i_1 i_2 j_1 j_2; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} \right) \\
 &\quad \times \epsilon_{j_1; \tilde{\alpha}_1}^F(t) \epsilon_{j_2; \tilde{\alpha}_2}^F(t).
 \end{aligned} \tag{\infty.105}$$

尤其是, 右端对步数的依赖完全由自由残余训练误差 $\epsilon_{j; \tilde{\alpha}}^F(t)$ 表示, 并且每一项关于 $\epsilon_{j; \tilde{\alpha}}^F(t)$ 都是线性或二次的. 因此, 为了求解这个差分方程并得到 $H_{i_1 i_2; \delta_1 \delta_2}^I(t)$, 只需计算这些项的求和.

其中一个和——关于自由残余训练误差的线性项——正是动力学辅助函数 $a_{j; \tilde{\alpha}}(t) \equiv \eta \sum_{s=0}^{t-1} \epsilon_{j; \tilde{\alpha}}^F(s)$, 它已在 (∞.92) 中求出. 另一类和关于自由残余训练误差是二次的, 由此定义第二个动力学辅助函数:

$$\begin{aligned}
 & b_{j_1 j_2; \tilde{\alpha}_1 \tilde{\alpha}_2}(t) \\
 & \equiv \eta \sum_{s=0}^{t-1} \epsilon_{j_1; \tilde{\alpha}_1}^F(s) \epsilon_{j_2; \tilde{\alpha}_2}^F(s) \\
 &= \eta \sum_{k_1, k_2, \tilde{\alpha}_3, \tilde{\alpha}_4} \sum_{s=0}^{t-1} \left[\left(I - \eta \hat{H} \right)^s \right]_{j_1 k_1; \tilde{\alpha}_1 \tilde{\alpha}_3} \left[\left(I - \eta \hat{H} \right)^s \right]_{j_2 k_2; \tilde{\alpha}_2 \tilde{\alpha}_4} (z_{k_1; \tilde{\alpha}_3} - y_{k_1; \tilde{\alpha}_3}) (z_{k_2; \tilde{\alpha}_4} - y_{k_2; \tilde{\alpha}_4}) \\
 &= \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4} X_{II}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \left[(z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) - \epsilon_{j_1; \tilde{\alpha}_3}^F(t) \epsilon_{j_2; \tilde{\alpha}_4}^F(t) \right] + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.106}$$

为计算这个和, 我们再次把自由残余训练误差的表达式 (∞.88) 与步演化算子的定义 (∞.89) 联用. 随后, 以引入次领先修正为代价, 把训练集的随机 NTK $\hat{H}_{ij; \tilde{\alpha}_1 \tilde{\alpha}_2}$ 替换成其均值 $\delta_{ij} H_{\tilde{\alpha}_1 \tilde{\alpha}_2}$, 并像 (∞.92) 中那样形式地完成几何求和. 最后一步产生一个求逆张量 $X_{II}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$, 其隐式定义为

$$\begin{aligned}
 \delta_{\tilde{\alpha}_5}^{\tilde{\alpha}_1} \delta_{\tilde{\alpha}_6}^{\tilde{\alpha}_2} &= \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} X_{II}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \frac{1}{\eta} \left[\delta_{\tilde{\alpha}_3 \tilde{\alpha}_5} \delta_{\tilde{\alpha}_4 \tilde{\alpha}_6} - (\delta_{\tilde{\alpha}_3 \tilde{\alpha}_5} - \eta \tilde{H}_{\tilde{\alpha}_3 \tilde{\alpha}_5}) (\delta_{\tilde{\alpha}_4 \tilde{\alpha}_6} - \eta \tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_6}) \right] \\
 &= \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} X_{II}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \left(\tilde{H}_{\tilde{\alpha}_3 \tilde{\alpha}_5} \delta_{\tilde{\alpha}_4 \tilde{\alpha}_6} + \delta_{\tilde{\alpha}_3 \tilde{\alpha}_5} \tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_6} - \eta \tilde{H}_{\tilde{\alpha}_3 \tilde{\alpha}_5} \tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_6} \right). \tag{\infty.107}
 \end{aligned}$$

这个张量是矩阵几何求和中熟悉的求逆矩阵 $X_I^{\tilde{\alpha}_1 \tilde{\alpha}_2} \equiv \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2}$ 的推广; 后者满足

$$\delta_{\tilde{\alpha}_3}^{\tilde{\alpha}_1} = \sum_{\tilde{\alpha}_2 \in \mathcal{A}} X_I^{\tilde{\alpha}_1 \tilde{\alpha}_2} \frac{1}{\eta} \left[\delta_{\tilde{\alpha}_2 \tilde{\alpha}_3} - (\delta_{\tilde{\alpha}_2 \tilde{\alpha}_3} - \eta \tilde{H}_{\tilde{\alpha}_2 \tilde{\alpha}_3}) \right] = \sum_{\tilde{\alpha}_2 \in \mathcal{A}} X_I^{\tilde{\alpha}_1 \tilde{\alpha}_2} \tilde{H}_{\tilde{\alpha}_2 \tilde{\alpha}_3}, \tag{\infty.108}$$

并曾出现在动力学辅助函数 $a_{j;\tilde{\alpha}}(t)$ 的最终表达式 (∞.92) 中. 趁着我们像被激活的神经元一样火力全开, 再为自由残余训练误差的三次项之和定义最后一个动力学辅助函数:

$$\begin{aligned}
 & c_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3}(t) \\
 & \equiv \eta \sum_{s=0}^t \epsilon_{j_1; \tilde{\alpha}_1}^F(t) \epsilon_{j_2; \tilde{\alpha}_2}^F(t) \epsilon_{j_3; \tilde{\alpha}_3}^F(t) \\
 & = \sum_{\tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} X_{\text{III}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \left[(z_{k_1; \tilde{\alpha}_4} - y_{k_1; \tilde{\alpha}_4}) (z_{k_2; \tilde{\alpha}_5} - y_{k_2; \tilde{\alpha}_5}) (z_{k_3; \tilde{\alpha}_6} - y_{k_3; \tilde{\alpha}_6}) \right. \\
 & \quad \left. - \epsilon_{j_1; \tilde{\alpha}_4}^F(t) \epsilon_{j_2; \tilde{\alpha}_5}^F(t) \epsilon_{j_3; \tilde{\alpha}_6}^F(t) \right] + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.109}$$

在此情形下, 求逆张量 $X_{\text{III}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ 的隐式定义为

$$\begin{aligned}
 & \delta_{\tilde{\alpha}_7}^{\tilde{\alpha}_1} \delta_{\tilde{\alpha}_8}^{\tilde{\alpha}_2} \delta_{\tilde{\alpha}_9}^{\tilde{\alpha}_3} \\
 & = \sum_{\tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} X_{\text{III}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \left[\left(\tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_7} \delta_{\tilde{\alpha}_5 \tilde{\alpha}_8} \delta_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \delta_{\tilde{\alpha}_4 \tilde{\alpha}_7} \tilde{H}_{\tilde{\alpha}_5 \tilde{\alpha}_8} \delta_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \delta_{\tilde{\alpha}_4 \tilde{\alpha}_7} \delta_{\tilde{\alpha}_5 \tilde{\alpha}_8} \tilde{H}_{\tilde{\alpha}_6 \tilde{\alpha}_9} \right) \right. \\
 & \quad \left. - \eta \left(\tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_7} \tilde{H}_{\tilde{\alpha}_5 \tilde{\alpha}_8} \delta_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_7} \delta_{\tilde{\alpha}_5 \tilde{\alpha}_8} \tilde{H}_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \delta_{\tilde{\alpha}_4 \tilde{\alpha}_7} \tilde{H}_{\tilde{\alpha}_5 \tilde{\alpha}_8} \tilde{H}_{\tilde{\alpha}_6 \tilde{\alpha}_9} \right) \right. \\
 & \quad \left. + \eta^2 \left(\tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_7} \tilde{H}_{\tilde{\alpha}_5 \tilde{\alpha}_8} \tilde{H}_{\tilde{\alpha}_6 \tilde{\alpha}_9} \right) \right].
 \end{aligned} \tag{\infty.110}$$

本质上, 这三个动力学辅助函数编码了自由残余训练误差各种几何和的步数依赖性. 注意

$$a_{j_1; \tilde{\alpha}_1}(t=0) = 0, \tag{\infty.111}$$

$$b_{j_1 j_2; \tilde{\alpha}_1 \tilde{\alpha}_2}(t=0) = 0, \tag{\infty.112}$$

$$c_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3}(t=0) = 0, \tag{\infty.113}$$

所以它们在初始化时全都为零; 而在训练终点,

$$a_{j_1; \tilde{\alpha}_1}(\infty) = \sum_{\tilde{\alpha}_2} X_{\text{I}}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j_1; \tilde{\alpha}_2} - y_{j_1; \tilde{\alpha}_2}) + O\left(\frac{1}{n}\right), \tag{\infty.114}$$

$$b_{j_1 j_2; \tilde{\alpha}_1 \tilde{\alpha}_2}(\infty) = \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4} X_{\text{II}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) + O\left(\frac{1}{n}\right), \tag{\infty.115}$$

$$\begin{aligned}
 c_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3}(\infty) & = \sum_{\tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} X_{\text{III}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & \quad + O\left(\frac{1}{n}\right),
 \end{aligned} \tag{\infty.116}$$

因为自由残余训练误差 $\epsilon_{j;\tilde{\alpha}}^F(t)$ 会指数快速地消失, 参见 (∞.90).

借助前两个动力学辅助函数, 可以把相互作用 NTK 的差分方程 (∞.105) 的解较为

紧凑地写成

$$\begin{aligned}
 & H_{i_1 i_2; \delta_1 \delta_2}^I(t) \\
 = & - \sum_{j, \tilde{\alpha}} \left(\widehat{dH}_{i_1 i_2 j; \delta_1 \delta_2 \tilde{\alpha}} + \widehat{dH}_{i_2 i_1 j; \delta_2 \delta_1 \tilde{\alpha}} \right) a_{j; \tilde{\alpha}}(t) \\
 & + \sum_{j, k, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3} \left(\widehat{dd_I H}_{i_1 i_2 j k; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_{II} H}_{i_1 i_2 j k; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_{II} H}_{i_1 j i_2 k; \delta_1 \tilde{\alpha}_1 \delta_2 \tilde{\alpha}_2} \right. \\
 & \quad \left. + \widehat{dd_I H}_{i_2 i_1 j k; \delta_2 \delta_1 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_{II} H}_{i_2 i_1 j k; \delta_2 \delta_1 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_{II} H}_{i_2 j i_1 k; \delta_2 \tilde{\alpha}_1 \delta_1 \tilde{\alpha}_2} \right) \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_3} \left[(z_{k; \tilde{\alpha}_3} - y_{k; \tilde{\alpha}_3}) a_{j; \tilde{\alpha}_1}(t) - b_{j k; \tilde{\alpha}_1 \tilde{\alpha}_3}(t) \right] \\
 & + \frac{\eta}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} \left(\widehat{dd_I H}_{i_1 i_2 j_1 j_2; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} + \widehat{dd_I H}_{i_2 i_1 j_1 j_2; \delta_2 \delta_1 \tilde{\alpha}_1 \tilde{\alpha}_2} + 2 \widehat{dd_{II} H}_{i_1 i_2 j_1 j_2; \delta_1 \delta_2 \tilde{\alpha}_1 \tilde{\alpha}_2} \right) b_{j_1 j_2; \tilde{\alpha}_1 \tilde{\alpha}_2}(t).
 \end{aligned} \tag{\infty.117}$$

作为快速健全性检查, 由于辅助函数在初始化时为零, 即 (∞.111) 和 (∞.112), 相互作用 NTK 的零初始条件 (∞.99) 确实得到满足. 还可以代入 (∞.114) 和 (∞.115), 求出训练终点处 NTK 的变化. 特别地, NTK 的变化越大, 特征函数的演化就越大. 因此, 初始误差越大, 训练过程中发生的表征学习就越多. 最后, 还需要确定网络输出相互作用部分 $z_{i; \delta}^I(t)$ 对步数的依赖关系. 把自由-相互作用分解 (∞.94) 代入网络输出动力学 (∞.81), 并利用自由部分满足与步数无关的演化方程 (∞.86) 这一事实, 重新整理各项后便得到只关于相互作用部分的动力学方程:

$$z_{i; \delta}^I(t+1) = z_{i; \delta}^I(t) - \sum_{j, \tilde{\alpha}} \eta \hat{H}_{ij; \delta \tilde{\alpha}} z_{j; \tilde{\alpha}}^I(t) + \eta \mathbb{F}_{i; \delta}(t). \tag{\infty.118}$$

这里定义了一个阻尼力:

$$\begin{aligned}
 \mathbb{F}_{i; \delta}(t) \equiv & - \sum_{j, \tilde{\alpha}} H_{ij; \delta \tilde{\alpha}}^I(t) \epsilon_{j; \tilde{\alpha}}^F(t) + \frac{\eta}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} dH_{ij_1 j_2; \delta \tilde{\alpha}_1 \tilde{\alpha}_2}(t) \epsilon_{j_1; \tilde{\alpha}_1}^F(t) \epsilon_{j_2; \tilde{\alpha}_2}^F(t) \\
 & - \frac{\eta^2}{6} \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3} \widehat{dd_I H}_{ij_1 j_2 j_3; \delta \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \epsilon_{j_1; \tilde{\alpha}_1}^F(t) \epsilon_{j_2; \tilde{\alpha}_2}^F(t) \epsilon_{j_3; \tilde{\alpha}_3}^F(t).
 \end{aligned} \tag{\infty.119}$$

由于相互作用 NTK 与 dNTK 的动力学已经分别由 (∞.117) 和 (∞.102) 用自由残余训练误差解 $\epsilon_{j; \tilde{\alpha}}^F(t)$ 表示出来, 这个阻尼力就是步数 t 的一个显式已知函数.

现在尝试把这个差分方程 (∞.118) 的解隐式地表示为对步数的求和. 首先, 对训练集中的输入 $\tilde{\alpha} \in \mathcal{A}$, 输出相互作用部分的动力学 (∞.118) 退化为一阶非齐次线性差分方程, 其中阻尼力破坏了齐次性:

$$z_{i; \tilde{\alpha}}^I(t+1) = \sum_{j, \tilde{\alpha}_1} \left(I_{ij; \tilde{\alpha} \tilde{\alpha}_1} - \eta \hat{H}_{ij; \tilde{\alpha} \tilde{\alpha}_1} \right) z_{j; \tilde{\alpha}_1}^I(t) + \eta \mathbb{F}_{i; \tilde{\alpha}}(t). \tag{\infty.120}$$

可以把这个方程形式地求解为阻尼力与自由步演化算子 (∞.89) 的卷积:

$$z_{i; \tilde{\alpha}}^I(t) = \eta \sum_{s=0}^{t-1} \sum_{j, \tilde{\alpha}_1} U_{ij; \tilde{\alpha} \tilde{\alpha}_1}(t-1-s) \mathbb{F}_{j; \tilde{\alpha}_1}(s), \tag{\infty.121}$$

它满足初始条件 $z_{i;\tilde{\alpha}}^I(t=0) = 0$. 再把这个结果代回一般输入 $\delta \in \mathcal{D}$ 的动力学方程 (∞.118), 便得到这类一般输入下网络输出相互作用部分的解:

$$z_{i;\delta}^I(t) = \eta \sum_{s=0}^{t-1} \left[\mathbb{F}_{i;\delta}(s) - \sum_{j,\tilde{\alpha}} \hat{H}_{ij;\delta\tilde{\alpha}} z_{j;\tilde{\alpha}}^I(s) \right]. \quad (\infty.122)$$

为了进一步化简这些表达式, 需要计算下面这个有些曲折的和:

$$\begin{aligned} \eta \sum_{s=0}^{t-1} z_{j;\tilde{\alpha}}^I(s) &= \eta^2 \sum_{s=0}^{t-1} \sum_{\tilde{s}=0}^{s-1} \sum_{k,\tilde{\alpha}_1} U_{jk;\tilde{\alpha}\tilde{\alpha}_1}(s-1-\tilde{s}) \mathbb{F}_{k;\tilde{\alpha}_1}(\tilde{s}) \\ &= \eta \sum_{u=0}^{t-2} \sum_{k,\tilde{\alpha}_1} \left[\eta \sum_{\tilde{u}=0}^{t-u-2} U_{jk;\tilde{\alpha}\tilde{\alpha}_1}(\tilde{u}) \right] \mathbb{F}_{k;\tilde{\alpha}_1}(u) \\ &= \eta \sum_{u=0}^{t-2} \sum_{k,m,\tilde{\alpha}_1,\tilde{\alpha}_2} \left(\hat{H}^{-1} \right)_{jm}^{\tilde{\alpha}\tilde{\alpha}_2} [I - U(t-u-1)]_{mk;\tilde{\alpha}_2\tilde{\alpha}_1} \mathbb{F}_{k;\tilde{\alpha}_1}(u) \\ &= \sum_{m,\tilde{\alpha}_2} \left(\hat{H}^{-1} \right)_{jm}^{\tilde{\alpha}\tilde{\alpha}_2} \left\{ \left[\eta \sum_{u=0}^{t-2} \mathbb{F}_{m;\tilde{\alpha}_2}(u) \right] + [\eta \mathbb{F}_{m;\tilde{\alpha}_2}(t-1) - z_{m;\tilde{\alpha}_2}^I(t)] \right\} \\ &= \sum_{m,\tilde{\alpha}_2} \left(\hat{H}^{-1} \right)_{jm}^{\tilde{\alpha}\tilde{\alpha}_2} \left\{ \left[\eta \sum_{u=0}^{t-1} \mathbb{F}_{m;\tilde{\alpha}_2}(u) \right] - z_{m;\tilde{\alpha}_2}^I(t) \right\}, \end{aligned} \quad (\infty.123)$$

逐行来看, 第一行使用了形式解 (∞.121); 第二行先把求和顺序反转为 $\sum_{s=0}^{t-1} \sum_{\tilde{s}=0}^{s-1} = \sum_{\tilde{s}=0}^{t-2} \sum_{s=\tilde{s}+1}^{t-1}$, 再用新变量 $u \equiv \tilde{s}$ 与 $\tilde{u} \equiv s-1-\tilde{s}$ 改写这些求和; 第三行像 (∞.92) 中那样精确完成了几何求和; 第四行使用第 t 步的形式解 (∞.121); 最后一行则合并各项, 把对阻尼力求和的上限延拓了. 把这个计算结果代回 $z_{i;\delta}^I(t)$ 的形式解 (∞.122), 得到一个不那么形式化的解:

$$z_{i;\delta}^I(t) = \eta \sum_{s=0}^{t-1} \left[\mathbb{F}_{i;\delta}(s) - \sum_{\tilde{\alpha}_1,\tilde{\alpha}_2} H_{\delta\tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} \mathbb{F}_{i;\tilde{\alpha}_2}(s) \right] + \sum_{\tilde{\alpha}_1,\tilde{\alpha}_2} H_{\delta\tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} z_{i;\tilde{\alpha}_2}^I(t) + O\left(\frac{1}{n^2}\right). \quad (\infty.124)$$

在这个结果中, 我们把随机 NTK 替换成其均值 $\hat{H}_{ij;\delta_1\delta_2} \rightarrow \delta_{ij} H_{\delta_1,\delta_2}$, 因为其余每一项都已经正比于 dNTK 或 ddNTK. 作为快速健全性检查, 注意对训练集中的输入 $\delta \rightarrow \tilde{\alpha} \in \mathcal{A}$, 这个一般表达式会退化为关于 $z_{i;\tilde{\alpha}}^I(t)$ 的恒等式.

我们最终关心的是训练终点 $t \rightarrow \infty$ 的相互作用解. 与此前一样, 假设 η 与随机 NTK 的乘积足够小, 使得自由步演化算子

$$\lim_{t \rightarrow \infty} U(t) \propto \exp(-\eta \hat{H} t), \quad (\infty.125)$$

指数衰减到零.²⁶⁰ 于是, 对训练输入, 网络输出的相互作用部分 $z_{i;\tilde{\alpha}}^I(t)$ 将指数收敛到零:

$$\lim_{t \rightarrow \infty} z_{i;\tilde{\alpha}}^I(t) = 0. \quad (\infty.126)$$

²⁶⁰注意, 由于步演化算子 $U(t)$ 是在 (∞.89) 中由与步数无关的 NTK $\hat{H}_{ij;\delta\tilde{\alpha}}$ 构造的, 所以这里的收敛条件与脚注 257 所讨论的自由理论分析相同.

要说明这一点，只需注意阻尼力 (∞.119) 按

$$\lim_{s \rightarrow \infty} \mathbb{F}(s) \propto \exp(-\eta \hat{H} s), \quad (\infty.127)$$

指数衰减，因为它的领先行为线性正比于自由残余训练误差 $\epsilon_{j;\tilde{\alpha}}^F(t)$ 。结合 (∞.125)，这意味着相互作用解 (∞.121) 按如下方式收敛：

$$\begin{aligned} \lim_{t \rightarrow \infty} z_{i;\tilde{\alpha}}^I(t) &= \eta \lim_{t \rightarrow \infty} \sum_{s=0}^{t-1} \sum_{j, \tilde{\alpha}_1} U_{ij;\tilde{\alpha}\tilde{\alpha}_1}(t-1-s) \mathbb{F}_{j;\tilde{\alpha}_1}(s) \\ &\propto \lim_{t \rightarrow \infty} \left\{ \eta t \exp[-(t-1)\eta \hat{H}] \right\} = 0, \end{aligned} \quad (\infty.128)$$

这比自由解 $z_{i;\tilde{\alpha}}^F(t) \propto \exp(-\hat{H}t)$ 的收敛略慢。因而，训练算法总体上收敛：

$$\lim_{t \rightarrow \infty} z_{i;\tilde{\alpha}}(t) - y_{i;\tilde{\alpha}} = \lim_{t \rightarrow \infty} [z_{i;\tilde{\alpha}}^F(t) + z_{i;\tilde{\alpha}}^I(t)] - y_{i;\tilde{\alpha}} = 0, \quad (\infty.129)$$

这里还使用了自由解 (∞.90).²⁶¹ 顺带一提，而且这一点可能具有更广泛的意义：以上结果共同表明，对具有有限宽度和非零深度的现实深度神经网络，梯度下降会指数快速地收敛到零误差极小值；误差至多是有效理论截断 L/n 的二次阶。

对一般输入，输出的相互作用部分 $z_{i;\delta}^I(t)$ 由 (∞.124) 给出。考虑到训练集上的收敛性 (∞.126)，其训练终点极限退化为

$$\lim_{t \rightarrow \infty} z_{i;\delta}^I(t) = \left[\eta \sum_{s=0}^{\infty} \mathbb{F}_{i;\delta}(s) \right] - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\delta\tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} \left[\eta \sum_{s=0}^{\infty} \mathbb{F}_{i;\tilde{\alpha}_2}(s) \right]. \quad (\infty.130)$$

因此，只剩下对阻尼力完成无限求和：

$$\begin{aligned} \eta \sum_{s=0}^{\infty} \mathbb{F}_{i;\delta}(s) &\equiv - \sum_{j, \tilde{\alpha}_1} \left[\eta \sum_{s=0}^{\infty} H_{ij;\delta\tilde{\alpha}_1}^I(s) \epsilon_{j;\tilde{\alpha}_1}^F(s) \right] \\ &+ \frac{\eta}{2} \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2} \left[\eta \sum_{s=0}^{\infty} dH_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}(s) \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \right] \\ &- \frac{\eta^2}{6} \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3} \left[\eta \sum_{s=0}^{\infty} \widehat{dd_1} H_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}(s) \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \epsilon_{j_3;\tilde{\alpha}_3}^F(s) \right]. \end{aligned} \quad (\infty.131)$$

第三个和恰好是第三个动力学辅助函数 $c_{j_1j_2j_3;\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}(t)$ 的训练终点极限；我们已经在 (∞.116) 中计算过它，结果为

$$\begin{aligned} &\eta \sum_{s=0}^{\infty} \widehat{dd_1} H_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}(s) \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \epsilon_{j_3;\tilde{\alpha}_3}^F(s) \\ &= \sum_{\tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} \widehat{dd_1} H_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} X_{\text{III}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{j_3;\tilde{\alpha}_6} - y_{j_3;\tilde{\alpha}_6}). \end{aligned} \quad (\infty.132)$$

²⁶¹ 请记得，本节已经不再显式标示 $O(1/n^2)$ 修正。回顾充分训练条件 (∞.66)，结果 (∞.129) 应理解为在这类修正范围内成立；两步解 (∞.78) 中的情形与此类似。

这样还剩两个和需要计算. 我们慢慢来: 每一步都很简单, 但必须准确处理的项很多.

首先, 可以把 (∞.131) 中的第二个和计算为

$$\begin{aligned}
 & \eta \sum_{s=0}^{\infty} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}(s) \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \\
 &= \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2} \sum_{s=0}^{\infty} \left[\eta \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \right] \\
 & \quad - \sum_{k,\tilde{\alpha}_3,\tilde{\alpha}_4} \left(\widehat{dd_I H}_{ij_1j_2k;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + 2\widehat{dd_{II} H}_{ij_1j_2k;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right) \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_4} \sum_{s=0}^{\infty} \left\{ \eta \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) [z_{k;\tilde{\alpha}_4} - y_{k;\tilde{\alpha}_4} - \epsilon_{k;\tilde{\alpha}_4}^F(s)] \right\},
 \end{aligned} \tag{\infty.133}$$

这里代入了动力学 dNTK 的解 (∞.102), 并利用整个表达式在 $(\tilde{\alpha}_1, j_1) \leftrightarrow (\tilde{\alpha}_2, j_2)$ 下对称这一事实, 合并了两个 $dd_{II}H$ 项. 随后使用已经算出的和 (∞.115) 与 (∞.116), 得到

$$\begin{aligned}
 & \eta \sum_{s=0}^{\infty} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2}(s) \epsilon_{j_1;\tilde{\alpha}_1}^F(s) \epsilon_{j_2;\tilde{\alpha}_2}^F(s) \\
 &= \sum_{\tilde{\alpha}_3,\tilde{\alpha}_4} \widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2} X_{II}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} (z_{j_1;\tilde{\alpha}_3} - y_{j_1;\tilde{\alpha}_3}) (z_{j_2;\tilde{\alpha}_4} - y_{j_2;\tilde{\alpha}_4}) \\
 & \quad - \sum_{k,\tilde{\alpha}_3,\dots,\tilde{\alpha}_6} \left(\widehat{dd_I H}_{ij_1j_2k;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + 2\widehat{dd_{II} H}_{ij_1j_2k;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right) \\
 & \quad \times Y_1^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{k;\tilde{\alpha}_6} - y_{k;\tilde{\alpha}_6}).
 \end{aligned} \tag{\infty.134}$$

为了方便稍后汇总各项, 这里引入简写

$$Y_1^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} \equiv X_{II}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_4\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_6} - \sum_{\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_7} X_{III}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_7\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6}, \tag{\infty.135}$$

最后, 把 (∞.131) 中的第一个和写为

$$\begin{aligned}
 & \eta \sum_{s=0}^{\infty} H_{ij;\delta\tilde{\alpha}_1}^I(s) \epsilon_{j;\tilde{\alpha}_1}^F(s) \\
 &= - \sum_{k,\tilde{\alpha}_2} \left(\widehat{dH}_{ijk;\delta\tilde{\alpha}_1\tilde{\alpha}_2} + \widehat{dH}_{jik;\tilde{\alpha}_1\delta\tilde{\alpha}_2} \right) \sum_{s=0}^{\infty} \left[\eta \epsilon_{j;\tilde{\alpha}_1}^F(s) a_{k;\tilde{\alpha}_2}(s) \right] \\
 & \quad + \sum_{k_1,k_2,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4} \left(\widehat{dd_I H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{dd_{II} H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{dd_{II} H}_{ik_1jk_2;\delta\tilde{\alpha}_2\tilde{\alpha}_1\tilde{\alpha}_3} \right. \\
 & \quad \left. + \widehat{dd_I H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{dd_{II} H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{dd_{II} H}_{jk_1ik_2;\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3} \right) \\
 & \quad \times \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_4} \sum_{s=0}^{\infty} \left\{ \eta \epsilon_{j;\tilde{\alpha}_1}^F(s) \left[(z_{k_2;\tilde{\alpha}_4} - y_{k_2;\tilde{\alpha}_4}) a_{k_1;\tilde{\alpha}_2}(s) - b_{k_1k_2;\tilde{\alpha}_2\tilde{\alpha}_4}(s) \right] \right\} \\
 & \quad + \frac{\eta}{2} \sum_{k_1,k_2,\tilde{\alpha}_2,\tilde{\alpha}_3} \left(\widehat{dd_I H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{dd_I H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + 2\widehat{dd_{II} H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right) \\
 & \quad \times \sum_{s=0}^{\infty} \left[\eta \epsilon_{j;\tilde{\alpha}_1}^F(s) b_{k_1k_2;\tilde{\alpha}_2\tilde{\alpha}_3}(s) \right],
 \end{aligned} \tag{\infty.136}$$

其中代入了相互作用 NTK 的解 (∞.117). 接着, 用 (∞.92) 和 (∞.106) 代入辅助函数, 再对这些项完成额外的求和, 最后使用训练终点极限 (∞.114)–(∞.116), 得到

$$\begin{aligned}
 & \eta \sum_{s=0}^{\infty} H_{ij;\delta\tilde{\alpha}_1}^I(s) \epsilon_{j;\tilde{\alpha}_1}^F(s) \\
 &= - \sum_{k,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4} \left(\widehat{\mathrm{d}H}_{ijk;\delta\tilde{\alpha}_1\tilde{\alpha}_2} + \widehat{\mathrm{d}H}_{jik;\tilde{\alpha}_1\delta\tilde{\alpha}_2} \right) Y_2^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} (z_{j;\tilde{\alpha}_3} - y_{j;\tilde{\alpha}_3}) (z_{k;\tilde{\alpha}_4} - y_{k;\tilde{\alpha}_4}) \\
 &+ \sum_{k_1,k_2,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6} \left(\widehat{\mathrm{dd}_I H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{\mathrm{dd}_\Pi H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{\mathrm{dd}_\Pi H}_{ik_1jk_2;\delta\tilde{\alpha}_2\tilde{\alpha}_1\tilde{\alpha}_3} \right. \\
 &\quad \left. + \widehat{\mathrm{dd}_I H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{\mathrm{dd}_\Pi H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{\mathrm{dd}_\Pi H}_{jk_1ik_2;\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3} \right) \\
 &\quad \times Y_3^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j;\tilde{\alpha}_4} - y_{j;\tilde{\alpha}_4}) (z_{k_1;\tilde{\alpha}_5} - y_{k_1;\tilde{\alpha}_5}) (z_{k_2;\tilde{\alpha}_6} - y_{k_2;\tilde{\alpha}_6}) \\
 &+ \frac{\eta}{2} \sum_{k_1,k_2,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6} \left(\widehat{\mathrm{dd}_I H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} + \widehat{\mathrm{dd}_I H}_{jik_1k_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} + 2\widehat{\mathrm{dd}_\Pi H}_{ijk_1k_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right) \\
 &\quad \times Y_4^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j;\tilde{\alpha}_4} - y_{j;\tilde{\alpha}_4}) (z_{k_1;\tilde{\alpha}_5} - y_{k_1;\tilde{\alpha}_5}) (z_{k_2;\tilde{\alpha}_6} - y_{k_2;\tilde{\alpha}_6}) ,
 \end{aligned} \tag{\infty.137}$$

其中又引入了如下简写:

$$Y_2^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} \equiv \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2\tilde{\alpha}_4} - \sum_{\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_2\tilde{\alpha}_5} X_{\Pi}^{\tilde{\alpha}_1\tilde{\alpha}_5\tilde{\alpha}_3\tilde{\alpha}_4}, \tag{\infty.138}$$

$$\begin{aligned}
 Y_3^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} &\equiv \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_2\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_6} - \sum_{\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_2\tilde{\alpha}_7} X_{\Pi}^{\tilde{\alpha}_1\tilde{\alpha}_7\tilde{\alpha}_4\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_6} \\
 &\quad - \sum_{\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_7} X_{\Pi}^{\tilde{\alpha}_2\tilde{\alpha}_7\tilde{\alpha}_5\tilde{\alpha}_6} + \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8,\tilde{\alpha}_9} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_9} X_{\Pi}^{\tilde{\alpha}_2\tilde{\alpha}_9\tilde{\alpha}_7\tilde{\alpha}_8} X_{\Pi}^{\tilde{\alpha}_1\tilde{\alpha}_7\tilde{\alpha}_8\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6},
 \end{aligned} \tag{\infty.139}$$

$$Y_4^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} \equiv \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_4} X_{\Pi}^{\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_5\tilde{\alpha}_6} - \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8} X_{\Pi}^{\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_7\tilde{\alpha}_8} X_{\Pi}^{\tilde{\alpha}_1\tilde{\alpha}_7\tilde{\alpha}_8\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6}. \tag{\infty.140}$$

现在, 该疯狂地来回翻页, 把之前算出的所有结果汇总起来了. 把求和结果 (∞.137)、(∞.134) 和 (∞.132) 代回阻尼力求和的表达式 (∞.131), 再把它代回网络输出相互作用部分的表达式 (∞.130), 最后与网络输出的自由部分 (∞.93) 合并, 便得到由梯度下降

训练的有限宽网络的充分训练解:

$$\begin{aligned}
 & z_{i;\delta}(t = \infty) \\
 & \equiv z_{i;\delta}^F(t = \infty) + z_{i;\delta}^I(t = \infty) \\
 & = z_{i;\delta} - \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{H}_{ij;\delta\tilde{\alpha}_1} \left(\widehat{H}^{-1} \right)_{jk}^{\tilde{\alpha}_1\tilde{\alpha}_2} (z_{k;\tilde{\alpha}_2} - y_{k;\tilde{\alpha}_2}) \\
 & + \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4} \left[\widehat{dH}_{j_1ij_2;\tilde{\alpha}_1\delta\tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5,\tilde{\alpha}_6} H_{\delta\tilde{\alpha}_5} \widetilde{H}^{\tilde{\alpha}_5\tilde{\alpha}_6} \widehat{dH}_{j_1ij_2;\tilde{\alpha}_1\tilde{\alpha}_6\tilde{\alpha}_2} \right] \\
 & \quad \times Z_A^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} (z_{j_1;\tilde{\alpha}_3} - y_{j_1;\tilde{\alpha}_3}) (z_{j_2;\tilde{\alpha}_4} - y_{j_2;\tilde{\alpha}_4}) \\
 & + \sum_{j_1,j_2,\tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4} \left[\widehat{dH}_{ij_1j_2;\delta\tilde{\alpha}_1\tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5,\tilde{\alpha}_6} H_{\delta\tilde{\alpha}_5} \widetilde{H}^{\tilde{\alpha}_5\tilde{\alpha}_6} \widehat{dH}_{ij_1j_2;\tilde{\alpha}_6\tilde{\alpha}_1\tilde{\alpha}_2} \right] \\
 & \quad \times Z_B^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} (z_{j_1;\tilde{\alpha}_3} - y_{j_1;\tilde{\alpha}_3}) (z_{j_2;\tilde{\alpha}_4} - y_{j_2;\tilde{\alpha}_4}) \\
 & + \sum_{\substack{j_1,j_2,j_3, \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6}} \left[\widehat{dd_I H}_{j_1ij_2j_3;\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8} H_{\delta\tilde{\alpha}_7} \widetilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_I H}_{j_1ij_2j_3;\tilde{\alpha}_1\tilde{\alpha}_8\tilde{\alpha}_2\tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IA}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{j_3;\tilde{\alpha}_6} - y_{j_3;\tilde{\alpha}_6}) \\
 & + \sum_{\substack{j_1,j_2,j_3, \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6}} \left[\widehat{dd_I H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8} H_{\delta\tilde{\alpha}_7} \widetilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_I H}_{ij_1j_2j_3;\tilde{\alpha}_8\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IB}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{j_3;\tilde{\alpha}_6} - y_{j_3;\tilde{\alpha}_6}) \\
 & + \sum_{\substack{j_1,j_2,j_3, \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6}} \left[\widehat{dd_{II} H}_{j_1j_2ij_3;\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8} H_{\delta\tilde{\alpha}_7} \widetilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_{II} H}_{j_1j_2ij_3;\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_8\tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IIA}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{j_3;\tilde{\alpha}_6} - y_{j_3;\tilde{\alpha}_6}) \\
 & + \sum_{\substack{j_1,j_2,j_3, \\ \tilde{\alpha}_1,\tilde{\alpha}_2,\tilde{\alpha}_3,\tilde{\alpha}_4,\tilde{\alpha}_5,\tilde{\alpha}_6}} \left[\widehat{dd_{II} H}_{ij_1j_2j_3;\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7,\tilde{\alpha}_8} H_{\delta\tilde{\alpha}_7} \widetilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_{II} H}_{ij_1j_2j_3;\tilde{\alpha}_8\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IIB}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} (z_{j_1;\tilde{\alpha}_4} - y_{j_1;\tilde{\alpha}_4}) (z_{j_2;\tilde{\alpha}_5} - y_{j_2;\tilde{\alpha}_5}) (z_{j_3;\tilde{\alpha}_6} - y_{j_3;\tilde{\alpha}_6}) \\
 & + O\left(\frac{1}{n^2}\right).
 \end{aligned} \tag{\infty.141}$$

这里用最后一个字母（以及各式各样的下标）定义最后一组张量：

$$Z_{\tilde{A}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv Y_2^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}, \quad (\infty.142)$$

$$Z_{\tilde{B}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv Y_2^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} + \frac{\eta}{2} X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}, \quad (\infty.143)$$

$$Z_{\tilde{IA}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - \frac{\eta}{2} Y_4^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}, \quad (\infty.144)$$

$$Z_{\tilde{IB}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - \frac{\eta}{2} Y_4^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - \frac{\eta}{2} Y_1^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - \frac{\eta^2}{6} X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}, \quad (\infty.145)$$

$$Z_{\tilde{\Pi A}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}, \quad (\infty.146)$$

$$Z_{\tilde{\Pi B}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - Y_3^{\tilde{\alpha}_2 \tilde{\alpha}_1 \tilde{\alpha}_3 \tilde{\alpha}_5 \tilde{\alpha}_4 \tilde{\alpha}_6} - Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_3 \tilde{\alpha}_2 \tilde{\alpha}_4 \tilde{\alpha}_6 \tilde{\alpha}_5} - \eta Y_4^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - \eta Y_1^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}, \quad (\infty.147)$$

这里使用了此前的简写张量 (∞.135) 和 (∞.138)–(∞.140).²⁶² 这些**算法投影算子**，即 (∞.142)–(∞.147)，按照梯度下降算法的具体细节，把初始训练误差分别投影到 dNTK 的两个不同组合、第一个 ddNTK 的两个不同组合，以及第二个 ddNTK 的另外两个不同组合上。作为最后的健全性检查，注意对训练集中的输入 $\delta \rightarrow \tilde{\alpha} \in \mathcal{A}$ ，有限宽解 (∞.141) 方括号中的每个量都消失，从而恢复充分训练条件 (∞.66)。在结束本小节之前，让我们进一步说明算法依赖性。首先注意，两次更新的解 (∞.79) 与梯度下降解 (∞.141) 具有相同的形式，但算法投影算子不同：

$$Z_{\tilde{B}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv \frac{1}{2} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4}, \quad Z_{\tilde{IB}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -\frac{1}{6} \tilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_4} \tilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_6}, \quad (\infty.148)$$

而其余投影算子全都为零。显然，这些算法具有非常不同的归纳偏置！

其次，通过取 $\eta \rightarrow 0$ ，我们可以研究该动力学的 ODE 极限，参见脚注 258：在这种情况下，可以看到 ODE 动力学的解为

$$Z_{\tilde{A}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} = Z_{\tilde{B}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \equiv Y_2^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}, \quad (\infty.149)$$

$$Z_{\tilde{IA}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} = Z_{\tilde{IB}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} = Z_{\tilde{\Pi A}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \quad (\infty.150)$$

$$Z_{\tilde{\Pi B}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \equiv -Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} - Y_3^{\tilde{\alpha}_2 \tilde{\alpha}_1 \tilde{\alpha}_3 \tilde{\alpha}_5 \tilde{\alpha}_4 \tilde{\alpha}_6} - Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_3 \tilde{\alpha}_2 \tilde{\alpha}_4 \tilde{\alpha}_6 \tilde{\alpha}_5}, \quad (\infty.151)$$

其中， $Y_2^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ 和 $Y_3^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ 分别由 (∞.138) 和 (∞.139) 给出，而反演张量 $X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ ，即 (∞.107)，现在满足

$$\sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \left(\tilde{H}_{\tilde{\alpha}_3 \tilde{\alpha}_5} \delta_{\tilde{\alpha}_4 \tilde{\alpha}_6} + \delta_{\tilde{\alpha}_3 \tilde{\alpha}_5} \tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_6} \right) = \delta_{\tilde{\alpha}_5}^{\tilde{\alpha}_1} \delta_{\tilde{\alpha}_6}^{\tilde{\alpha}_2}, \quad (\infty.152)$$

另一个反演张量 $X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ ，即 (∞.110)，现在满足

$$\begin{aligned} & \delta_{\tilde{\alpha}_7}^{\tilde{\alpha}_1} \delta_{\tilde{\alpha}_8}^{\tilde{\alpha}_2} \delta_{\tilde{\alpha}_9}^{\tilde{\alpha}_3} \\ &= \sum_{\tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} X_{\tilde{\Pi}}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} \left(\tilde{H}_{\tilde{\alpha}_4 \tilde{\alpha}_7} \delta_{\tilde{\alpha}_5 \tilde{\alpha}_8} \delta_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \delta_{\tilde{\alpha}_4 \tilde{\alpha}_7} \tilde{H}_{\tilde{\alpha}_5 \tilde{\alpha}_8} \delta_{\tilde{\alpha}_6 \tilde{\alpha}_9} + \delta_{\tilde{\alpha}_4 \tilde{\alpha}_7} \delta_{\tilde{\alpha}_5 \tilde{\alpha}_8} \tilde{H}_{\tilde{\alpha}_6 \tilde{\alpha}_9} \right). \end{aligned} \quad (\infty.153)$$

²⁶²注意，对最后一个张量 (∞.147)，为了把解 (∞.141) 中的各种贡献整理成合适的形式，我们使用了 $\widehat{\text{dd}_{\Pi} \tilde{H}}_{ij_1 j_2 j_3; \delta \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3}$ 的对称性，并重新标记了若干哑样本指标。

这些结果完整刻画了梯度流与梯度下降对于这些充分训练网络的差异.

一般而言, 我们猜想: 对于有限宽网络, 在领先阶上, 充分训练解具有 (∞.141) 的普适形式, 而全部算法依赖性都编码在六个算法投影算子中: $Z_A^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ 、 $Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ 、 $Z_{IA}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ 、 $Z_{IB}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ 、 $Z_{IIA}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$ 和 $Z_{IIB}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6}$.²⁶³

最后, 让我们理解解 (∞.141) 中余项的含义. 它并不真正是某个实例化后又通过许许多多步梯度下降得到充分训练的实际网络的误差, 而是我们对这个特定充分训练网络的有效描述所具有的误差. 当然, 如果有兴趣, 我们的有效理论形式体系可以计算更高阶修正. 不过, 领先阶有限宽修正对于大多数情形确实应当足够: 例如, 对于深度为 $L = 10$ 层、每个隐藏层宽度为 $n = 100$ 个神经元的网络, 我们的有效描述只会相差 $\sim (L/n)^2 = 1\%$.

此外, 对任何理论分析而言, 解的主要定性差异出现在从无限宽过渡到有限宽时, 因为此时我们从自由理论过渡到相互作用理论, 并从线性动力学过渡到非线性动力学. 因而, 在仍能极其精确地描述真实深度学习模型的同时, 给出解 (∞.141) 的有效理论确实达到了尽可能简单的程度.

∞.2.3 有限宽下的预测

我们已经用两种不同方式求解了训练动力学, 因此现在可以相当一般地研究网络对测试集中新输入 $x_{\tilde{\beta}}$ ($\tilde{\beta} \in \mathcal{B}$) 的预测.

²⁶³更准确地说, 我们猜想: 上述猜想对 MSE 损失成立. 对于交叉熵损失, 解的形式会略有不同, 但仍会类似地划分为算法无关部分与算法相关部分, 后者由类似的算法投影算子描述.

在有限宽下，充分训练网络的预测普适地由如下随机方程支配：

$$\begin{aligned}
 & z_{i;\dot{\beta}}(t=T) \\
 = & z_{i;\dot{\beta}} - \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\dot{\beta}\tilde{\alpha}_1} \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} (z_{i;\tilde{\alpha}_2} - y_{i;\tilde{\alpha}_2}) \\
 & + \sum_{j, \tilde{\alpha}_1, \tilde{\alpha}_2} \left[\widehat{\Delta H}_{ij;\dot{\beta}\tilde{\alpha}_1} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4 \in \mathcal{A}} H_{\dot{\beta}\tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_4} \widehat{\Delta H}_{ij;\tilde{\alpha}_4\tilde{\alpha}_1} \right] \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2}) \\
 & - \sum_{j,k, \tilde{\alpha}_1, \dots, \tilde{\alpha}_4} \left[\widehat{\Delta H}_{ij;\dot{\beta}\tilde{\alpha}_1} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6} H_{\dot{\beta}\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_5\tilde{\alpha}_6} \widehat{\Delta H}_{ij;\tilde{\alpha}_6\tilde{\alpha}_1} \right] \tilde{H}^{\tilde{\alpha}_1\tilde{\alpha}_2} \widehat{\Delta H}_{jk;\tilde{\alpha}_2\tilde{\alpha}_3} \tilde{H}^{\tilde{\alpha}_3\tilde{\alpha}_4} (z_{k;\tilde{\alpha}_4} - y_{k;\tilde{\alpha}_4}) \\
 & + \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4} \left[\widehat{dH}_{j_1 j_2; \tilde{\alpha}_1 \dot{\beta} \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6} H_{\dot{\beta}\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_5\tilde{\alpha}_6} \widehat{dH}_{j_1 j_2; \tilde{\alpha}_1 \tilde{\alpha}_6 \tilde{\alpha}_2} \right] \\
 & \quad \times Z_A^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\
 & + \sum_{j_1, j_2, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4} \left[\widehat{dH}_{ij_1 j_2; \dot{\beta} \tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_5, \tilde{\alpha}_6} H_{\dot{\beta}\tilde{\alpha}_5} \tilde{H}^{\tilde{\alpha}_5\tilde{\alpha}_6} \widehat{dH}_{ij_1 j_2; \tilde{\alpha}_6 \tilde{\alpha}_1 \tilde{\alpha}_2} \right] \\
 & \quad \times Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} (z_{j_1; \tilde{\alpha}_3} - y_{j_1; \tilde{\alpha}_3}) (z_{j_2; \tilde{\alpha}_4} - y_{j_2; \tilde{\alpha}_4}) \\
 & + \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} \left[\widehat{dd_I H}_{j_1 j_2 j_3; \tilde{\alpha}_1 \dot{\beta} \tilde{\alpha}_2 \tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7, \tilde{\alpha}_8} H_{\dot{\beta}\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_I H}_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_8 \tilde{\alpha}_2 \tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IA}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & + \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} \left[\widehat{dd_I H}_{ij_1 j_2 j_3; \dot{\beta} \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7, \tilde{\alpha}_8} H_{\dot{\beta}\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_I H}_{ij_1 j_2 j_3; \tilde{\alpha}_8 \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IB}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & + \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} \left[\widehat{dd_{II} H}_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_2 \dot{\beta} \tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7, \tilde{\alpha}_8} H_{\dot{\beta}\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_{II} H}_{j_1 j_2 j_3; \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_8 \tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IIA}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & + \sum_{j_1, j_2, j_3, \tilde{\alpha}_1, \tilde{\alpha}_2, \tilde{\alpha}_3, \tilde{\alpha}_4, \tilde{\alpha}_5, \tilde{\alpha}_6} \left[\widehat{dd_{II} H}_{ij_1 j_2 j_3; \dot{\beta} \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} - \sum_{\tilde{\alpha}_7, \tilde{\alpha}_8} H_{\dot{\beta}\tilde{\alpha}_7} \tilde{H}^{\tilde{\alpha}_7\tilde{\alpha}_8} \widehat{dd_{II} H}_{ij_1 j_2 j_3; \tilde{\alpha}_8 \tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3} \right] \\
 & \quad \times Z_{IIB}^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4 \tilde{\alpha}_5 \tilde{\alpha}_6} (z_{j_1; \tilde{\alpha}_4} - y_{j_1; \tilde{\alpha}_4}) (z_{j_2; \tilde{\alpha}_5} - y_{j_2; \tilde{\alpha}_5}) (z_{j_3; \tilde{\alpha}_6} - y_{j_3; \tilde{\alpha}_6}) \\
 & + O\left(\frac{1}{n^2}\right).
 \end{aligned}
 \tag{\infty.154}$$

这个公式勉强可以印在一件 T 恤上。²⁶⁴ 在这个表达式中，我们按照 (∞.71) 展开了随机 NTK 子张量的完整逆；具体而言，第二行差不多就是无限宽核预测 (10.39)，第三、四行则是由 NTK 涨落引起的有限宽修正。此外，算法投影算子 (∞.142)–(∞.147) 包含了

²⁶⁴为了更好地促进这种品牌认知，先回忆：对于近核方法，我们可以用训练后核 (11.142) 压缩模型预

解的全部有限宽算法依赖性, 因此这个一般解 (∞.154) 能够描述我们的两个显式解: 无论是用两步 (∞.79)、许许多多步 (∞.141), 还是用采用 MSE 损失的任何其他优化算法进行训练.

而且, 这个解 (∞.154) 描述了系综中某个特定网络的预测: 逐实现差异编码在特定的初始网络输出 z 、NTK 涨落 $\widehat{\Delta H}$ 、dNTK $\widehat{dH}$ 、第一个 ddNTK $\widehat{dd_I H}$ 和第二个 ddNTK $\widehat{dd_{II} H}$ 中. 由于我们明确知道这些变量在初始化时的统计量, 也就可以完整分析充分训练分布的统计量. 为了随后讨论这些统计量的深度依赖性, 现在重新启用层指标.

首先, 均值预测为

$$\begin{aligned} m_{i;\beta} &\equiv \mathbb{E} \left[z_{i;\beta}^{(L)}(T) \right] \\ &= m_{i;\beta}^{\text{NTK}} + \frac{1}{n_{L-1}} \left(m_{i;\beta}^{\Delta \text{NTK}} + m_{i;\beta}^{\text{dNTK}} + m_{i;\beta}^{\text{ddNTK-I}} + m_{i;\beta}^{\text{ddNTK-II}} \right) \\ &\quad - \frac{1}{n_{L-1}} \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\beta \tilde{\alpha}_1}^{(L)} \widetilde{H}_{(L)}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \left(m_{i;\tilde{\alpha}_2}^{\Delta \text{NTK}} + m_{i;\tilde{\alpha}_2}^{\text{dNTK}} + m_{i;\tilde{\alpha}_2}^{\text{ddNTK-I}} + m_{i;\tilde{\alpha}_2}^{\text{ddNTK-II}} \right) + O\left(\frac{1}{n^2}\right), \end{aligned} \quad (\infty.160)$$

测; 类似地, 也可以用训练后 NTK $H_{ij;\delta\tilde{\alpha}}^\sharp$ 压缩有限宽网络的预测 (∞.154):

$$z_{i;\beta}(t=T) = z_{i;\beta} - \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} H_{ij;\beta\tilde{\alpha}_1}^\sharp \widetilde{H}_{jk}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{k;\tilde{\alpha}_2} - y_{k;\tilde{\alpha}_2}) + O\left(\frac{1}{n^2}\right), \quad (\infty.155)$$

它具有 (神经正切) 核预测 (10.39) 的形式. 为了看清这一点, 将训练后 NTK 分解为自由项和依赖于训练的项:

$$H_{ij;\delta\tilde{\alpha}}^\sharp \equiv \widehat{H}_{ij;\delta\tilde{\alpha}} + \mathbb{H}_{ij;\delta\tilde{\alpha}}. \quad (\infty.156)$$

不要把这个分解与先前的分解 (∞.95) 混淆: 先前的分解便于求解训练动力学, 而这个新分解用于确定 (∞.155) 中的训练后 NTK. 考虑训练后 NTK 仅限制在训练集上的逆:

$$\widetilde{H}_{jk}^{\tilde{\alpha}_1 \tilde{\alpha}_2} \equiv \left(\widehat{H}^{-1} \right)_{jk}^{\tilde{\alpha}_1 \tilde{\alpha}_2} - \sum_{\tilde{\alpha}_3, \tilde{\alpha}_4} \mathbb{H}_{jk;\tilde{\alpha}_3 \tilde{\alpha}_4} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_3} \widetilde{H}^{\tilde{\alpha}_2 \tilde{\alpha}_4} + O\left(\frac{1}{n^2}\right), \quad (\infty.157)$$

把它与分解 (∞.156) 一同代入公式 (∞.155), 得到

$$\begin{aligned} z_{i;\beta}(t=T) &= z_{i;\beta} - \sum_{j,k,\tilde{\alpha}_1,\tilde{\alpha}_2} \widehat{H}_{ij;\beta\tilde{\alpha}_1} \left(\widehat{H}^{-1} \right)_{jk}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{k;\tilde{\alpha}_2} - y_{k;\tilde{\alpha}_2}) \\ &\quad - \sum_{j,\tilde{\alpha}_1,\tilde{\alpha}_2} \left[\mathbb{H}_{ij;\beta\tilde{\alpha}_1} - \sum_{\tilde{\alpha}_3,\tilde{\alpha}_4} H_{\beta\tilde{\alpha}_3} \widetilde{H}^{\tilde{\alpha}_3 \tilde{\alpha}_4} \mathbb{H}_{ij;\tilde{\alpha}_4 \tilde{\alpha}_1} \right] \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2}) + O\left(\frac{1}{n^2}\right). \end{aligned} \quad (\infty.158)$$

该式右边第一行给出解的自由贡献 (∞.93), 第二行则给出相互作用贡献 (∞.130), 概括了有限宽下非平凡表征学习的效应. $H_{ij;\delta\tilde{\alpha}}^\sharp$ 的具体形式可以通过匹配 (∞.158) 和 (∞.154) 右边的各项求得. 还可以用阻尼力 (∞.119) 隐式表示依赖于训练的部分 $\mathbb{H}_{ij;\delta\tilde{\alpha}}$:

$$\eta \sum_{s=0}^{\infty} \mathbb{F}_{i;\delta}(s) = - \sum_{j,\tilde{\alpha}_1,\tilde{\alpha}_2} \mathbb{H}_{ij;\delta\tilde{\alpha}_1} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2}), \quad (\infty.159)$$

比较 (∞.158) 与 (∞.130) 即可看清这一点. 这个隐式表达式还清楚表明, $\mathbb{H}_{ij;\delta\tilde{\alpha}}$ 的形式并不唯一: 总可以给它加上与 $\sum_{\tilde{\alpha}_2} \widetilde{H}^{\tilde{\alpha}_1 \tilde{\alpha}_2} (z_{j;\tilde{\alpha}_2} - y_{j;\tilde{\alpha}_2})$ 正交的项来调整它. 无论如何, 有了训练后 NTK, 现在就可以把有限宽预测公式 (∞.155) 印在任何新生 AI 的连体衣上了.

其中第一项是（神经正切）核预测

$$m_{i;\dot{\beta}}^{\text{NTK}} \equiv \sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\dot{\beta}\tilde{\alpha}_1}^{(L)} \tilde{H}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} y_{i;\tilde{\alpha}_2}, \quad (\infty.161)$$

而另外四类项来自领先阶有限宽修正. 具体而言, (i) NTK 涨落给出

$$m_{i;\delta}^{\Delta\text{NTK}} \equiv \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4} \left(A_{(\delta\tilde{\alpha}_1)(\tilde{\alpha}_2\tilde{\alpha}_3)}^{(L)} + B_{\delta\tilde{\alpha}_2\tilde{\alpha}_1\tilde{\alpha}_3}^{(L)} + n_L B_{\delta\tilde{\alpha}_3\tilde{\alpha}_1\tilde{\alpha}_2}^{(L)} \right) \tilde{H}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2} \tilde{H}_{(L)}^{\tilde{\alpha}_3\tilde{\alpha}_4} y_{i;\tilde{\alpha}_4} \quad (\infty.162)$$

这里使用 (8.82), 借助张量 $A^{(L)}$ 和 $B^{(L)}$ 的分解来计算 NTK 方差; (ii) dNTK 给出

$$m_{i;\delta}^{\text{dNTK}} \equiv - \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4} \left[2 \left(P_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + Q_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + n_L Q_{\delta\tilde{\alpha}_2\tilde{\alpha}_1\tilde{\alpha}_3}^{(L)} \right) Z_B^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} \right. \\ \left. + \left(n_L P_{\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + Q_{\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + Q_{\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3}^{(L)} \right) Z_A^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4} \right. \\ \left. + \left(P_{\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + n_L Q_{\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} + Q_{\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3}^{(L)} \right) Z_A^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_4\tilde{\alpha}_3} \right] y_{i;\tilde{\alpha}_4}, \quad (\infty.163)$$

这里使用 (11.42), 借助张量 $P^{(L)}$ 和 $Q^{(L)}$ 的分解来计算 dNTK-预激活交叉关联; (iii) 第一个 ddNTK 给出

$$m_{i;\delta}^{\text{ddNTK-I}} \equiv - \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_6} \left[R_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} \left(Z_{\text{IB}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} + Z_{\text{IB}}^{\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_1\tilde{\alpha}_5\tilde{\alpha}_6\tilde{\alpha}_4} + Z_{\text{IB}}^{\tilde{\alpha}_3\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_6\tilde{\alpha}_4\tilde{\alpha}_5} \right) \right. \\ \left. + R_{\tilde{\alpha}_1\delta\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} Z_{\text{IA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} + R_{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\delta}^{(L)} Z_{\text{IA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_5\tilde{\alpha}_6\tilde{\alpha}_4} + R_{\tilde{\alpha}_1\tilde{\alpha}_3\delta\tilde{\alpha}_2}^{(L)} Z_{\text{IA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_6\tilde{\alpha}_4\tilde{\alpha}_5} \right] \\ \times \left[y_{i;\tilde{\alpha}_4} \left(\sum_j y_{j;\tilde{\alpha}_5} y_{j;\tilde{\alpha}_6} + n_L K_{\tilde{\alpha}_5\tilde{\alpha}_6}^{(L)} \right) + y_{i;\tilde{\alpha}_5} K_{\tilde{\alpha}_6\tilde{\alpha}_4}^{(L)} + y_{i;\tilde{\alpha}_6} K_{\tilde{\alpha}_4\tilde{\alpha}_5}^{(L)} \right] \quad (\infty.164)$$

这里使用 (∞.11), 借助张量 $R^{(L)}$ 的分解来计算第一个 ddNTK 的均值; (iv) 第二个 ddNTK 给出

$$m_{i;\delta}^{\text{ddNTK-II}} \equiv - \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_6} \left[S_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} Z_{\text{IIB}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} + T_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} Z_{\text{IIB}}^{\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_1\tilde{\alpha}_5\tilde{\alpha}_6\tilde{\alpha}_4} + U_{\delta\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3}^{(L)} Z_{\text{IIB}}^{\tilde{\alpha}_3\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_6\tilde{\alpha}_4\tilde{\alpha}_5} \right. \\ \left. + S_{\tilde{\alpha}_1\tilde{\alpha}_2\delta\tilde{\alpha}_3}^{(L)} Z_{\text{IIA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_5\tilde{\alpha}_6\tilde{\alpha}_4} + T_{\tilde{\alpha}_1\delta\tilde{\alpha}_3\tilde{\alpha}_2}^{(L)} Z_{\text{IIA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_4\tilde{\alpha}_5\tilde{\alpha}_6} + U_{\tilde{\alpha}_1\tilde{\alpha}_3\tilde{\alpha}_2\delta}^{(L)} Z_{\text{IIA}}^{\tilde{\alpha}_1\tilde{\alpha}_2\tilde{\alpha}_3\tilde{\alpha}_6\tilde{\alpha}_4\tilde{\alpha}_5} \right] \\ \times \left[y_{i;\tilde{\alpha}_4} \left(\sum_j y_{j;\tilde{\alpha}_5} y_{j;\tilde{\alpha}_6} + n_L K_{\tilde{\alpha}_5\tilde{\alpha}_6}^{(L)} \right) + y_{i;\tilde{\alpha}_5} K_{\tilde{\alpha}_6\tilde{\alpha}_4}^{(L)} + y_{i;\tilde{\alpha}_6} K_{\tilde{\alpha}_4\tilde{\alpha}_5}^{(L)} \right] \quad (\infty.165)$$

这里使用 (∞.12), 借助张量 $S^{(L)}$ 、 $T^{(L)}$ 和 $U^{(L)}$ 的分解来计算第二个 ddNTK 的均值.

有趣的是, 均值预测不仅依赖 NTK 微分——鉴于有限宽下存在非平凡表征学习, 这正是我们所预期的——还依赖 NTK 方差, 参见 (∞.162). 这是自然的, 因为每个网络都用它自己特定的 NTK 拟合训练数据, 所以所得的特定充分训练输出 (∞.154) 依赖于 NTK 涨落, 正如我们已经强调的那样. 一般而言, 理解这两种贡献之间的权衡确实

非常重要；在下一个无编号小节中，我们将回来讨论整个系综中随机涨落与定向表征学习之间的这种相互作用。

此外，观察 ddNTK 贡献中关于 $y_{i;\tilde{\alpha}}$ 为三次的项，即 (∞.164) 和 (∞.165)，可以看到：当 $i \neq j$ 时，观测输出的第 j 个分量会影响均值预测的第 i 个分量。正如我们对贝叶斯推断均值预测 (6.88) 所见，这是有限宽神经网络布线性质的后果。为了观察这种布线性质的另一种表现，考虑协方差：

$$\text{Cov}\left[z_{i_1;\dot{\beta}_1}^{(L)}(T), z_{i_2;\dot{\beta}_2}^{(L)}(T)\right] \equiv \mathbb{E}\left[z_{i_1;\dot{\beta}_1}^{(L)}(T) z_{i_2;\dot{\beta}_2}^{(L)}(T)\right] - \mathbb{E}\left[z_{i_1;\dot{\beta}_1}^{(L)}(T)\right] \mathbb{E}\left[z_{i_2;\dot{\beta}_2}^{(L)}(T)\right]. \quad (\infty.166)$$

我们不会完整写出这个量——完整表达式实在不太适合页面尺寸——但考察一些具体贡献就很容易提取见解。例如，考察协方差的如下贡献，可以看到输出分量布线留下的印记：

$$\begin{aligned} & \sum_{\substack{j_1, j_2 \\ \tilde{\alpha}_1, \dots, \tilde{\alpha}_4}} \mathbb{E}\left[z_{i_2;\dot{\beta}_2}^{(L)} \widehat{dH}_{i_1 j_1 j_2; \dot{\beta}_1 \tilde{\alpha}_1 \tilde{\alpha}_2}^{(L)}\right] Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \mathbb{E}\left[\left(z_{j_1;\tilde{\alpha}_3}^{(L)} - y_{j_1;\tilde{\alpha}_3}\right) \left(z_{j_2;\tilde{\alpha}_4}^{(L)} - y_{j_2;\tilde{\alpha}_4}\right)\right] \\ &= \frac{1}{n_{L-1}} \delta_{i_1 i_2} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4} \left[\left(n_L P_{\dot{\beta}_1 \tilde{\alpha}_1 \tilde{\alpha}_2 \dot{\beta}_2}^{(L)} + Q_{\dot{\beta}_1 \tilde{\alpha}_1 \tilde{\alpha}_2 \dot{\beta}_2}^{(L)} + Q_{\dot{\beta}_1 \tilde{\alpha}_2 \tilde{\alpha}_1 \dot{\beta}_2}^{(L)} \right) G_{\tilde{\alpha}_3 \tilde{\alpha}_4}^{(L)} \right. \\ & \quad \left. + P_{\dot{\beta}_1 \tilde{\alpha}_1 \tilde{\alpha}_2 \dot{\beta}_2}^{(L)} \left(\sum_j y_{j;\tilde{\alpha}_3} y_{j;\tilde{\alpha}_4} \right) \right] Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} \\ & + \frac{1}{n_{L-1}} \sum_{\tilde{\alpha}_1, \dots, \tilde{\alpha}_4} Q_{\dot{\beta}_1 \tilde{\alpha}_1 \tilde{\alpha}_2 \dot{\beta}_2}^{(L)} Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4} (y_{i_1;\tilde{\alpha}_3} y_{i_2;\tilde{\alpha}_4} + y_{i_1;\tilde{\alpha}_4} y_{i_2;\tilde{\alpha}_3}), \quad (\infty.167) \end{aligned}$$

它来自 $z_{i_2;\dot{\beta}_2}^{(L)}(T)$ 中的一个 $z_{i_2;\dot{\beta}_2}^{(L)}$ 因子与 $z_{i_1;\dot{\beta}_1}^{(L)}(T)$ 中一个含算法投影算子 $Z_B^{\tilde{\alpha}_1 \tilde{\alpha}_2 \tilde{\alpha}_3 \tilde{\alpha}_4}$ 的 dNTK 项之间的交叉关联。具体来说，当真实输出在 i_1 和 i_2 两个分量上都非零时，最后一行的末项表现出布线。在这种情况下，当 $i_1 \neq i_2$ 时，关联 (∞.167) 意味着：给定 $z_{i_2;\dot{\beta}_2}^{(L)}(T)$ ，测试集预测 $z_{i_1;\dot{\beta}_1}^{(L)}(T)$ 可以发生偏移；参见我们在 §6.4.1 中依据有限宽先验里的共同激发归纳偏置对 Hebb 学习所作的相关讨论，以及随后在 §6.4.2 中关于它如何导致后验分布连接在一起的讨论。在这里，解的协方差中存在这种布线，意味着系综中每个网络的这一布线贡献都不同：初始化时参数的逐实现涨落打破了输出神经元之间的置换对称性。这种布线表明，每个网络都能利用不同初始输出分量之间的涨落，在学习过程中把这些分量关联起来。

更广泛地说，不同于无限宽下的核预测 (10.39)，有限宽下的预测 (∞.154) 现在具有非高斯统计。具体而言，有限宽预测是初始化时网络输出、NTK、dNTK 和 ddNTK 的非平凡泛函，而我们知道这些量的联合分布 $p\left(z^{(L)}, \widehat{H}^{(L)}, \widehat{dH}^{(L)}, \widehat{dd_1 H}^{(L)}, \widehat{dd_{II} H}^{(L)} \middle| \mathcal{D}\right)$ 是近高斯分布，因此充分训练分布 $p\left(z^{(L)}(T) \middle| \mathcal{D}\right)$ 也是如此。特别地，它具有非平凡的高阶连通关联量；这些关联量的显式表达式很难用任何媒介格式展示，不过 (∞.154) 已经包含写出它们所需的全部信息，而且锁定任何特定的感兴趣项并不困难。这些关联量承载的信息很可能有助于理解充分训练网络的一些行为，值得进一步研究。

有限宽下的泛化

我们已经讨论了有限宽预测 (∞.154) 与无限宽核预测 (10.39) 之间的许多定性差异, 现在来作一些定量陈述. 为了从高层次理解有限宽下的泛化相对于我们在 §10.3 中所作的大量无限宽分析会如何改变, 需要确定预测中有限宽修正的相对重要性, 即这些修正如何依赖隐藏层宽度 n_ℓ 和网络深度 L . 特别地, 我们想理解有限宽下广义偏差-方差权衡 (10.52) 的修正.

先考虑偏差项 $m_{i;\dot{\beta}} - y_{i;\dot{\beta}}$, 为此只需考察 (∞.160) 中的均值预测 $m_{i;\dot{\beta}}$. 具体而言, 需要把第一项 (∞.161)——它差不多对应无限宽核预测 $m_{i;\dot{\beta}}^\infty$, 只差 NTK 均值的次领先且不重要的修正——与均值的另一组有限宽贡献 (∞.162)–(∞.165) 比较.

在 (∞.160) 的有限宽贡献中, 第一组大括号内的各项在张量 $A^{(L)}$ 、 $B^{(L)}$ 、 $P^{(L)}$ 、 $Q^{(L)}$ 、 $R^{(L)}$ 、 $S^{(L)}$ 、 $T^{(L)}$ 和 $U^{(L)}$ 中都含有一个对应于测试输入 $\dot{\beta}$ 的样本指标. 因而, 即使训练集只有一个训练样本, 正如我们在 §10.3.1 中研究的那样, 这些项的具体细节也要求理解 NTK 方差、预激活-dNTK 交叉关联和 ddNTK 均值递推的渐近多输入解; 这种分析有点麻烦, 先前被留作寻求刺激者的冒险, 给感兴趣读者的简短说明手册则藏在 §11.3 的脚注 218 中. 遗憾的是, 我们打算在这里继续更新那份手册, 而且预计不这样做也不会漏掉多少东西.²⁶⁵

相比之下, (∞.160) 中第二组大括号内的项可以用手头已有的结果分析. 因此, 为了用少量工作非线性地获得大量直觉, 只把无限宽项 (∞.161) 与最后这组项比较. 具体而言, 由于这两项前面都有共同的前因子 $\sum_{\tilde{\alpha}_1, \tilde{\alpha}_2} H_{\dot{\beta}\tilde{\alpha}_1}^{(L)} \tilde{H}_{(L)}^{\tilde{\alpha}_1\tilde{\alpha}_2}$ ——其效应已经在 §10.3 中分析过——只需理解 (∞.160) 中第二组方括号内张量的深度与宽度依赖性. 这里将对单个训练集输入 $x_{\tilde{\alpha}} = x$ 计算这些张量; 为简化记号, 在余下分析中省略训练样本指标.

为了看清物理, 最简单的是考察许许多多步梯度下降的 ODE 极限 $\eta \searrow 0$; 此时算法投影算子具有特别简单的形式:

$$Z_A = Z_B = \frac{1}{2 \left(\tilde{H}^{(L)} \right)^2}, \quad Z_{IA} = Z_{IB} = Z_{IIA} = \frac{-1}{6 \left(\tilde{H}^{(L)} \right)^3}, \quad Z_{IIB} = \frac{-1}{2 \left(\tilde{H}^{(L)} \right)^3}, \quad (\infty.168)$$

这些表达式可由 (∞.138)、(∞.139) 和 (∞.149)–(∞.153) 推得.²⁶⁶ 把这些投影算子 (∞.168) 代入均值预测的 dNTK 和 ddNTK 贡献 (∞.163)–(∞.165), 再考察均值预测 $m_{i;\dot{\beta}}$ 的 $1/n$ 部分 (∞.160), 可以看到每一项都正比于下列某个无量纲比:

²⁶⁵ 具体而言, 我们预计第一组项的定性行为会与下一段将讨论的第二组项类似, 不过具体的 $O(1)$ 层面细节可能不同.

²⁶⁶ 离开 ODE 极限, 对于学习率有限的许许多多步梯度下降, 单输入 dNTK 算法投影算子 (∞.142) 和 (∞.143) 改为

$$Z_A = \frac{1}{\left(\tilde{H}^{(L)} \right)^2} \left(\frac{1 - \eta \tilde{H}^{(L)}}{2 - \eta \tilde{H}^{(L)}} \right), \quad Z_B = \frac{1}{2 \left(\tilde{H}^{(L)} \right)^2}. \quad (\infty.169)$$

结合 ddNTK 算法投影算子的类似单输入极限, 这意味着同一组比值 (∞.170) 仍决定泛化误差的偏差项, 不过现在还带有额外的 η 依赖性. 特别地, 当全局学习率从下方趋近 $\eta \nearrow 2/\tilde{H}^{(L)}$ 时, 投影算子 Z_A 发散. 这种发散符合预期: 正如脚注 257 所指出的, 要使训练动力学在许许多多步之后 $t \rightarrow \infty$ 收敛, 需要 $\|I - \eta \hat{H}\| < 1$. 检查后还会发现, 一些 ddNTK 算法投影算子也具有相同的发散.

$$\begin{aligned} & \frac{A^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^2}, \quad \frac{B^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^2}, \quad \frac{P^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^2}, \quad \frac{Q^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^2}, \quad (\infty.170) \\ & \frac{R^{(L)} K^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^3}, \quad \frac{S^{(L)} K^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^3}, \quad \frac{T^{(L)} K^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^3}, \quad \frac{U^{(L)} K^{(L)}}{n_{L-1} \left(\tilde{H}^{(L)} \right)^3}. \end{aligned}$$

因此，与领先无限宽项相比，这八个比值决定了有限宽效应的大小。²⁶⁷

重要的是，回忆 NTK 方差的标度律 (9.27)、dNTK-预激活交叉关联的标度律 (11.65)，以及 ddNTK-预激活交叉关联的标度律 (∞.21) 和 (∞.22)，可以看到这些无量纲比中的每一个都像深宽比 L/n 那样标度（次主导的 $U^{(L)}$ 贡献除外）。

因此，总体上有限宽修正应满足

$$m_{i;\hat{\beta}} - m_{i;\hat{\beta}}^{\infty} = O\left(\frac{L}{n}\right), \quad (\infty.171)$$

其中精确的 $O(1)$ 常数并不重要。重要的是，我们证实了对该修正整体标度的预期：它按有效理论的截断尺度 $r \equiv L/n$ 标度。类似地，也可以考察协方差 (∞.166)，分析泛化误差的方差项；这会做大量工作却几乎没有回报，只会确认领先有限宽修正同样为 $O(L/n)$ 阶。

一般而言，既然深宽比 L/n 同时控制系统综中的涨落和表征学习，其最优值很可能非零但较小。具体而言，深度会增强表征学习，但 L/n 过大的网络不仅会影响系统综均值预测，而且也许更重要的是，在只处理某个特定网络时会导致指数级严重的问题：当 L/n 足够大时，典型性原理可能失效，于是泛化误差会开始呈现指数行为。²⁶⁸

这进一步解释了 $O(L/n)$ 阶有效理论描述为何成功： L/n 消失的描述，即无限宽极限，过于简单，无法刻画实际深度神经网络的性质；较大 L/n 的描述，即包含许多高阶修正的小宽度或过深区域，描述的是不太可能训练成功的网络；小而非零 L/n 的描述，即精确到 $O(L/n)$ 的领先有限宽有效理论，已经尽可能简单，同时仍能准确描述实践中表现良好的网络。²⁶⁹

总之，我们已经看到，所有领先有限宽修正都严格按照长期以来的预期标度，并从高层次讨论了深度与宽度之间潜在的权衡。原则上可以继续分析：计算邻近输入的多输

²⁶⁷顺便说一下，(∞.170) 第一行最后两个比值的形式，最终说明了为什么在 (11.62) 中要用两个 NTK 均值因子除 dNTK-预激活交叉关联张量；参见 (11.64) 附近关于量纲分析的讨论。类似地，(∞.170) 第二行四个比值的形式，最终说明了比值 (∞.21) 和 (∞.22) 的由来。对后面这组比值而言，严格说来应当写 $K^{(L)} + n_L^{-1} \sum_j y_j^2$ ，而不只是 $K^{(L)}$ ；尤其当 $K^{(L)}$ 表现为 L 的非平凡幂律时更是如此。在这种情况下，应当按照 (∞.26) 附近的讨论，用幂律因子 $L^{-p_0/2}$ 重标度目标输出 $y_{i;\tilde{\alpha}}$ 。

²⁶⁸在 §5.4 对涨落的讨论中，我们说明了过大的 L/n 可能造成棘手的精细调节问题，使某个特定网络难以表现出临界行为。

一方面，这类涨落对泛化误差偏差部分的贡献，展示了涨落的下游效应如何在训练后引发问题。另一方面，涨落能够破坏特定网络的临界性则是另一个问题。前一个问题影响整个系统综，后一个问题影响单个网络。

²⁶⁹要更好地理解可训练区域与过深区域之间的分界尺度，参见附录 A。关于在宽度固定时如何把可训练区域扩展到更大深度，参见附录 B 中对残差网络的讨论。

入递推、计算协方差中的所有项，并求出泛化误差中所有带具体系数的 $O(L/n)$ 贡献。²⁷⁰ 如果这样做，它能告诉我们什么？特别是，能否在不进行任何实验的情况下，从理论上优化某个特定激活函数的深宽比 L/n ？

遗憾的是，在当前工作阶数上，无法利用训练结束时的预测公式 (∞.154) 优化深宽比 L/n ：泛化对该比值的线性依赖意味着其导数与该比值无关；相反，需要计算 $O(L^2/n^2)$ 阶的高阶修正才能优化该比值——这很困难，但至少在已经建立的有效理论框架中是直接可行的。²⁷¹ 在 $O(L/n)$ 阶，最多只能通过总体系数的符号判断非零 L/n 是否改善泛化。与其费力进行那种分析，不如从均值预测 $m_{i;\beta}$ 中再挖掘一点信息，尝试理解有限宽度的算法依赖性如何在泛化误差的偏差项内部引出额外权衡。

训练算法的归纳偏置

正如多次提到的，通过基于梯度的学习优化时，无限宽网络与有限宽网络之间的一个关键区别，是有限宽网络的充分训练解具有算法依赖性。特别地，至少对于 MSE 损失，解具有普适形式 (∞.154)，而解对训练算法的全部依赖性都编码在算法投影算子 Z_A 、 Z_B 、 Z_{IA} 、 Z_{IB} 、 Z_{IIA} 和 Z_{IIB} 中。我们已经明确建立了它们的泛函形式：对两次二阶更新见 (∞.148)，对许许多多步梯度下降见 (∞.142)–(∞.147)，对梯度下降的 ODE 极限见 (∞.149)–(∞.151)。通过这种普适投影，现在从理论上可以把训练算法的归纳偏置同充分训练神经网络中的所有其他归纳偏置分离开来。这为从理论上评估不同训练算法的相对优劣提供了自然方法。

只要凝视随机预测式 (∞.154) 就能看出一点：算法投影算子只对有限宽预测的 NTK 微分部分施加投影，而不能影响 NTK 涨落贡献。更具体地说，继续讨论泛化误差的偏差项。偏差由如下差给出：

$$m_{i;\beta} - y_{i;\beta}. \quad (\infty.172)$$

一方面，均值预测中由 $A^{(L)}$ 和 $B^{(L)}$ 编码的 NTK 方差贡献 (∞.162) 显然不可约，并且完全独立于训练算法；这个不可约的 NTK 方差贡献以固定方式依赖训练数据，并源自不同参数实现之间 NTK 的逐实现涨落。另一方面，投影算子总是作用于 NTK 微分张量 $P^{(L)}$ 、 $Q^{(L)}$ 、 $R^{(L)}$ 、 $S^{(L)}$ 、 $T^{(L)}$ 和 $U^{(L)}$ ；这意味着 dNTK 和 ddNTK 对网络预测的影响可以由训练算法调节，并能针对不同数据集和任务作不同调整。

重申先前关于权衡的讨论：一方面，NTK 涨落贡献很可能有害，因为它会导致任意特定网络的临界性失效。另一方面，后一个 NTK 微分贡献是有限宽下非平凡表征学习的最终来源，因此最好让这一贡献较大。借助这些算法投影算子，现在可以直接增强后一个收益，同时保持前一个代价不变。

理解这些算法投影算子的一种方式，是把它们视为学习算法在样本空间中的对偶描

²⁷⁰也可以在考虑这一标度的情况下，更容易地数值计算相关递推的多输入版本，从而确定所关心的某个特定激活函数的总体系数。这是分析类 ReLU 的 GELU 和 SWISH 网络之解的一种方式。

²⁷¹在 §A.3 中，我们将从信息论角度计算这种高阶效应。这一分析将给出优化网络深宽比 r 的启发式方案：考虑一个被认为有利于构建表征的辅助无监督学习目标，并依据该准则而非泛化误差来优化深宽比。在这种设置中，通过权衡领先阶效应与高阶效应，可以确定不同激活函数的最优深宽比。这在精神上有些类似于 Newton 方法为了优化整体学习率而权衡损失的领先下降与次领先上升；参见 §10.2 中脚注 165 对 Newton 方法的讨论。

述，类似于我们在 §10.4 和 §11.4 中探讨的特征函数 $\phi_j(x)$ 与核 $k(x_{\delta_1}, x_{\delta_2})$ 之间的关系。从参数空间的微观视角看，梯度下降之类的学习算法显式作用于参数。训练结束时，算法的所有细节都隐含在训练后参数 θ^* 中，因此难以理解它对模型预测的影响。从这个视角看，算法很容易定义 (§7.2)，但对于一般的相互作用机器学习模型却显然难以分析 (§∞.2.2)。不过，如果能够分析或求解模型，找到它在样本空间中的对偶描述，算法投影算子就会使学习算法的影响变得显式。²⁷²

类似于从（近）核视角看（近）线性模型，算法投影算子出现在泛化误差中，意味着可以开始考虑直接设计它们：或者选取投影算子，直接用于 (∞.154) 这样的预测公式；或者尝试寻找某个算法投影算子在参数空间中的对偶。我们预计后一项任务会很困难——正如通常很难找到对应于某个特定核的特征函数——但把它作为直接设计训练算法归纳偏置的方法，很值得探索。²⁷³

特别地，我们预计，通过设计更适合架构细节或底层数据集、任务性质的算法，可以显著改善泛化。²⁷⁴ 原则上，这一设计过程可以如下进行：(i) 设计算法投影算子所需的泛函形式，然后 (ii) 确定能使投影算子具有这些所需性质或特定泛函形式的参数空间训练算法。虽然这种**逆算法设计**的进一步细节超出了本书范围，但我们认为，这条对偶分析路线有潜力让我们更深入地理解训练算法的归纳偏置、网络架构的归纳偏置与模型最终成功之间的关系。

梯度下降无处等于精确贝叶斯推断

最后，好奇的读者可能会想：我们在 §10.2.4 中详细说明了、无限宽极限下梯度下降优化与精确贝叶斯推断之间的联系，是否仍适用于有限宽下更现实的网络？简而言之，答案是否定的。

详细来说，回忆在无限宽下使基于梯度的学习与贝叶斯推断相匹配的训练超参数设置 (10.46) 和 (10.48)。特别地，后一个条件 (10.48) 要求关闭隐藏层中的全部学习：

$$\lambda_b^{(\ell)} = 0, \quad \lambda_w^{(\ell)} = 0, \quad \text{for } \ell < L. \quad (\infty.173)$$

重要的是，这使隐藏层 NTK 精确消失：在任意有限宽度下，对 $\ell < L$ 都有 $\hat{H}_{i_1 i_2; \delta_1 \delta_2}^{(\ell)} = 0$ ，参见 (8.12)。接着向前翻，查看 dNTK-预激活交叉关联张量的 P 和 Q 递推 (11.49) 和 (11.52)；然后你大概还会想继续向前翻，分别查看 F 和 B 递推 (8.79) 和 (8.89)。（我们会在这里等你回来。）你应当立刻注意到一个问题：如果隐藏层 NTK 均值消失，那么在此阶上 $B^{(\ell)} = 0$ 、 $F^{(\ell)} = 0$ ，这些结果合在一起意味着 $P^{(L)} = Q^{(L)} = 0$ 。因而，dNTK 的全部效应都被关闭。类似地，如果向后翻去查看 R 、 S 、 T 和 U 递推 (∞.177) 以及 (∞.179)–(∞.181)，就会发现 ddNTK 的全部效应也都被关闭。因此，有限宽、基于梯度学习的系综之均值预测 (∞.160) 在有限宽下不可能匹配精确贝叶斯后验均值 (6.88)。

注意，事后看来这种不匹配显而易见；只训练最后一层 (∞.173)，得到的是一个线性模型 (10.134)。换言之，由于 (∞.173) 的超参数选择导致模型具有在整个训练过程中

²⁷²这正是我们在 (0.9) 中所说的：对于训练后系综，以学习算法为条件将是简单的。

²⁷³这也可以视为非线性或相互作用机器学习模型的另一项优势。对线性模型而言，解总是独立于学习算法的细节 (§10.2.2)。

²⁷⁴由于算法投影算子带有样本指标，算法的最优选择通常不仅依赖模型定义，还依赖训练集的细节与结构。

保持固定的随机特征，这些设置不可能产生表征学习。相比之下，在 §6.4.3 研究有限宽下的精确贝叶斯推断时，我们发现了非平凡的表征学习。

归根结底，对贝叶斯推断而言，我们只关心预激活分布 $p(z^{(\ell)}|\mathcal{D})$ ；而对基于梯度的学习而言，需要考虑预激活-NTK-dNTK-ddNTK 的联合分布：

$p\left(z^{(L)}, \widehat{H}^{(L)}, \widehat{dH}^{(L)}, \widehat{dd_I H}^{(L)}, \widehat{dd_{II} H}^{(L)}|\mathcal{D}\right)$. 该分布包含初始化时预激活导数的统计量，而模型输出的这些导数对精确贝叶斯推断者不可见。

∞.3 ddNTK 的 RG 流：完整表达式

这些表达式相当可怕，所以我们决定把它们藏在本章末尾。因此，真正需要它们只有三个理由：(i) 显式检查超参数设置 (∞.173) 下不存在任何 NTK 微分，从而确认梯度下降与贝叶斯推断之间的联系在有限宽下不再成立；(ii) 检查我们在 §∞.1 中讨论的 ddNTK 深宽缩放的细节；以及 (iii) 更一般地针对多个输入，以解析或数值方式计算 ddNTK 对系综均值预测 (∞.164) 和 (∞.165) 的贡献，或计算随机预测 (∞.154) 的其他高阶统计量。

$\widehat{dd_I H}$ 随机前向方程

$$\begin{aligned}
 & \widehat{dd_I H}_{i_0 i_1 i_2 i_3; \delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} \\
 = & \delta_{i_0 i_1} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_0, j_1, j_2, j_3=1}^{n_\ell} \delta_{j_0 j_1} W_{i_2 j_2}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} \sigma_{j_1; \delta_1}^{(\ell)} \sigma'_{j_2; \delta_2}^{(\ell)} \sigma'_{j_3; \delta_3}^{(\ell)} \\
 & \times \left[\sigma''_{j_0; \delta_0}^{(\ell)} \widehat{H}_{j_0 j_2; \delta_0 \delta_2}^{(\ell)} \widehat{H}_{j_0 j_3; \delta_0 \delta_3}^{(\ell)} + \sigma'_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_2 j_3; \delta_0 \delta_2 \delta_3}^{(\ell)} \right] \\
 + & \delta_{i_0 i_2} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_0, j_1, j_2, j_3=1}^{n_\ell} \delta_{j_0 j_2} W_{i_3 j_3}^{(\ell+1)} W_{i_1 j_1}^{(\ell+1)} \sigma_{j_2; \delta_2}^{(\ell)} \sigma'_{j_3; \delta_3}^{(\ell)} \sigma'_{j_1; \delta_1}^{(\ell)} \\
 & \times \left[\sigma''_{j_0; \delta_0}^{(\ell)} \widehat{H}_{j_0 j_3; \delta_0 \delta_3}^{(\ell)} \widehat{H}_{j_0 j_1; \delta_0 \delta_1}^{(\ell)} + \sigma'_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_3 j_1; \delta_0 \delta_3 \delta_1}^{(\ell)} \right] \\
 + & \delta_{i_0 i_3} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_0, j_1, j_2, j_3=1}^{n_\ell} \delta_{j_0 j_3} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} \sigma_{j_3; \delta_3}^{(\ell)} \sigma'_{j_1; \delta_1}^{(\ell)} \sigma'_{j_2; \delta_2}^{(\ell)} \\
 & \times \left[\sigma''_{j_0; \delta_0}^{(\ell)} \widehat{H}_{j_0 j_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{j_0 j_2; \delta_0 \delta_2}^{(\ell)} + \sigma'_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_1 j_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \right] \\
 + & \sum_{j_0, j_1, j_2, j_3=1}^{n_\ell} W_{i_0 j_0}^{(\ell+1)} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} \sigma'_{j_1; \delta_1}^{(\ell)} \sigma'_{j_2; \delta_2}^{(\ell)} \sigma'_{j_3; \delta_3}^{(\ell)} \\
 & \times \left[\sigma'_{j_0; \delta_0}^{(\ell)} \widehat{dd_I H}_{j_0 j_1 j_2 j_3; \delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} + \sigma''_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_1 j_2; \delta_0 \delta_1 \delta_2}^{(\ell)} \widehat{H}_{j_0 j_3; \delta_0 \delta_3}^{(\ell)} \right. \\
 & + \sigma''_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_2 j_3; \delta_0 \delta_2 \delta_3}^{(\ell)} \widehat{H}_{j_0 j_1; \delta_0 \delta_1}^{(\ell)} + \sigma''_{j_0; \delta_0}^{(\ell)} \widehat{dH}_{j_0 j_3 j_1; \delta_0 \delta_3 \delta_1}^{(\ell)} \widehat{H}_{j_0 j_2; \delta_0 \delta_2}^{(\ell)} \\
 & \left. + \sigma'''_{j_0; \delta_0}^{(\ell)} \widehat{H}_{j_0 j_1; \delta_0 \delta_1}^{(\ell)} \widehat{H}_{j_0 j_2; \delta_0 \delta_2}^{(\ell)} \widehat{H}_{j_0 j_3; \delta_0 \delta_3}^{(\ell)} \right],
 \end{aligned} \tag{∞.174}$$

$\widehat{\text{dd}}_{\text{II}} H$ 随机前向方程

$$\begin{aligned}
 & \widehat{\text{dd}}_{\text{II}} H_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}^{(\ell+1)} \quad (\infty.175) \\
 = & \delta_{i_1 i_3} \delta_{i_2 i_4} \left(\frac{\lambda_W^{(\ell+1)}}{n_\ell} \right)^2 \sum_{j,k=1}^{n_\ell} \sigma'_{j;\delta_1}(\ell) \sigma'_{k;\delta_2}(\ell) \sigma_{j;\delta_3}(\ell) \sigma_{k;\delta_4}(\ell) \widehat{H}_{jk;\delta_1 \delta_2}^{(\ell)} \\
 & + \delta_{i_1 i_2} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_1, \dots, j_4=1}^{n_\ell} \delta_{j_1 j_2} W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \sigma'_{j_1;\delta_1}(\ell) \sigma'_{j_2;\delta_2}(\ell) \sigma'_{j_3;\delta_3}(\ell) \sigma'_{j_4;\delta_4}(\ell) \widehat{H}_{j_1 j_3; \delta_1 \delta_3}^{(\ell)} \widehat{H}_{j_2 j_4; \delta_2 \delta_4}^{(\ell)} \\
 & + \delta_{i_1 i_3} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_1, \dots, j_4=1}^{n_\ell} \delta_{j_1 j_3} W_{i_2 j_2}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \sigma_{j_3;\delta_3}^{(\ell)} \sigma'_{j_4;\delta_4}(\ell) \sigma'_{j_1;\delta_1}(\ell) \\
 & \quad \times \left[\sigma_{j_2;\delta_2}^{(\ell)} \widehat{H}_{j_2 j_1; \delta_2 \delta_1}^{(\ell)} \widehat{H}_{j_2 j_4; \delta_2 \delta_4}^{(\ell)} + \sigma'_{j_2;\delta_2}(\ell) \widehat{\text{d}} H_{j_2 j_1 j_4; \delta_2 \delta_1 \delta_4}^{(\ell)} \right] \\
 & + \delta_{i_2 i_4} \frac{\lambda_W^{(\ell+1)}}{n_\ell} \sum_{j_1, \dots, j_4=1}^{n_\ell} \delta_{j_2 j_4} W_{i_1 j_1}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} \sigma_{j_4;\delta_4}^{(\ell)} \sigma'_{j_3;\delta_3}(\ell) \sigma'_{j_2;\delta_2}(\ell) \\
 & \quad \times \left[\sigma_{j_1;\delta_1}^{(\ell)} \widehat{H}_{j_1 j_2; \delta_1 \delta_2}^{(\ell)} \widehat{H}_{j_1 j_3; \delta_1 \delta_3}^{(\ell)} + \sigma'_{j_1;\delta_1}(\ell) \widehat{\text{d}} H_{j_1 j_2 j_3; \delta_1 \delta_2 \delta_3}^{(\ell)} \right] \\
 & + \sum_{j_1, j_2, j_3, j_4=1}^{n_\ell} W_{i_1 j_1}^{(\ell+1)} W_{i_2 j_2}^{(\ell+1)} W_{i_3 j_3}^{(\ell+1)} W_{i_4 j_4}^{(\ell+1)} \sigma'_{j_3;\delta_3}(\ell) \sigma'_{j_4;\delta_4}(\ell) \\
 & \quad \times \left[\sigma'_{j_1;\delta_1}(\ell) \sigma'_{j_2;\delta_2}(\ell) \widehat{\text{dd}}_{\text{II}} H_{j_1 j_2 j_3 j_4; \delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} + \sigma_{j_1;\delta_1}^{(\ell)} \sigma_{j_2;\delta_2}^{(\ell)} \widehat{H}_{j_1 j_2; \delta_1 \delta_2}^{(\ell)} \widehat{H}_{j_1 j_3; \delta_1 \delta_3}^{(\ell)} \widehat{H}_{j_2 j_4; \delta_2 \delta_4}^{(\ell)} \right. \\
 & \quad \left. + \sigma'_{j_1;\delta_1}(\ell) \sigma_{j_2;\delta_2}^{(\ell)} \widehat{H}_{j_2 j_4; \delta_2 \delta_4}^{(\ell)} \widehat{\text{d}} H_{j_1 j_2 j_3; \delta_1 \delta_2 \delta_3}^{(\ell)} + \sigma'_{j_2;\delta_2}(\ell) \sigma_{j_1;\delta_1}^{(\ell)} \widehat{H}_{j_1 j_3; \delta_1 \delta_3}^{(\ell)} \widehat{\text{d}} H_{j_2 j_1 j_4; \delta_2 \delta_1 \delta_4}^{(\ell)} \right],
 \end{aligned}$$

$\widehat{\text{dd}}_{\text{I}} H$ 递推

第一个 ddNTK 的均值分解为

$$\begin{aligned}
 & \mathbb{E} \left[\widehat{\text{dd}}_{\text{I}} H_{i_0 i_1 i_2 i_3; \delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} \right] \quad (\infty.176) \\
 = & \frac{1}{n_{\ell-1}} \left[\delta_{i_0 i_1} \delta_{i_2 i_3} R_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} + \delta_{i_0 i_2} \delta_{i_3 i_1} R_{\delta_0 \delta_2 \delta_3 \delta_1}^{(\ell)} + \delta_{i_0 i_3} \delta_{i_1 i_2} R_{\delta_0 \delta_3 \delta_1 \delta_2}^{(\ell)} \right].
 \end{aligned}$$

张量 $R^{(\ell)}$ 满足如下逐层递推:

$$\begin{aligned}
 & R_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell+1)} \\
 = & \lambda_W^{(\ell+1)} C_W^{(\ell+1)} \langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} H_{\delta_0 \delta_2}^{(\ell)} H_{\delta_0 \delta_3}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} \right) \left(\lambda_W^{(\ell+1)} \langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} \right) B_{\delta_0 \delta_0 \delta_2 \delta_3}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} \right) \left[\lambda_W^{(\ell+1)} \left(\langle \sigma_{\delta_0}'' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} P_{\delta_0 \delta_2 \delta_3 \delta_0}^{(\ell)} + \langle \sigma_{\delta_0}' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} P_{\delta_0 \delta_2 \delta_3 \delta_1}^{(\ell)} \right) \right] \\
 & + \left(C_W^{(\ell+1)} \right)^2 \langle \sigma_{\delta_0}''' \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} H_{\delta_0 \delta_1}^{(\ell)} H_{\delta_0 \delta_2}^{(\ell)} H_{\delta_0 \delta_3}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_0}''' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} \right) B_{\delta_0 \delta_0 \delta_2 \delta_3}^{(\ell)} H_{\delta_0 \delta_1}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} \right) \left[C_W^{(\ell+1)} \left(\langle \sigma_{\delta_0}''' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} P_{\delta_0 \delta_2 \delta_3 \delta_0}^{(\ell)} + \langle \sigma_{\delta_0}'' \sigma_{\delta_1}'' \rangle_{G^{(\ell)}} P_{\delta_0 \delta_2 \delta_3 \delta_1}^{(\ell)} \right) \right] H_{\delta_0 \delta_1}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_2}' \sigma_{\delta_3}' \rangle_{G^{(\ell)}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_0}' \sigma_{\delta_1}' \rangle_{G^{(\ell)}} \right) R_{\delta_0 \delta_1 \delta_2 \delta_3}^{(\ell)} + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.177}$$

$\widehat{\text{dd}}_{\Pi} H$ 递推

第二个 ddNTK 的均值分解为

$$\begin{aligned}
 & \mathbb{E} \left[\widehat{\text{dd}}_{\Pi} H_{i_1 i_2 i_3 i_4; \delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} \right] \\
 = & \frac{1}{n_{\ell-1}} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} S_{\delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} + \delta_{i_1 i_3} \delta_{i_4 i_2} T_{\delta_1 \delta_3 \delta_4 \delta_2}^{(\ell)} + \delta_{i_1 i_4} \delta_{i_2 i_3} U_{\delta_1 \delta_4 \delta_2 \delta_3}^{(\ell)} \right].
 \end{aligned} \tag{\infty.178}$$

张量 $S^{(\ell)}$ 满足如下逐层递推:

$$\begin{aligned}
 & S_{\delta_1 \delta_2 \delta_3 \delta_4}^{(\ell+1)} \\
 = & C_W^{(\ell+1)} \lambda_W^{(\ell+1)} \langle \sigma_{\delta_1}' \sigma_{\delta_2}' \sigma_{\delta_3}' \sigma_{\delta_4}' \rangle_{G^{(\ell)}} H_{\delta_1 \delta_3}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_3}' \sigma_{\delta_4}' \rangle_{G^{(\ell)}} \right) \left[\lambda_W^{(\ell+1)} \langle \sigma_{\delta_1}' \sigma_{\delta_2}' \rangle_{G^{(\ell)}} + C_W^{(\ell+1)} H_{\delta_1 \delta_2}^{(\ell)} \langle \sigma_{\delta_1}'' \sigma_{\delta_2}'' \rangle_{G^{(\ell)}} \right] B_{\delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} \\
 & + \left(C_W^{(\ell+1)} \right)^2 \langle \sigma_{\delta_1}'' \sigma_{\delta_2}'' \sigma_{\delta_3}' \sigma_{\delta_4}' \rangle_{G^{(\ell)}} H_{\delta_1 \delta_2}^{(\ell)} H_{\delta_1 \delta_3}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_1}' \sigma_{\delta_2}' \rangle_{G^{(\ell)}} \right) \left(C_W^{(\ell+1)} \langle \sigma_{\delta_3}' \sigma_{\delta_4}' \rangle_{G^{(\ell)}} \right) S_{\delta_1 \delta_2 \delta_3 \delta_4}^{(\ell)} + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.179}$$

张量 $T^{(\ell)}$ 满足如下逐层递推:

$$\begin{aligned}
 & T_{\delta_1 \delta_3 \delta_4 \delta_2}^{(\ell+1)} \\
 = & \left(\lambda_W^{(\ell+1)} \right)^2 \langle \sigma'_{\delta_1} \sigma'_{\delta_2} \sigma_{\delta_3} \sigma_{\delta_4} \rangle_{G^{(\ell)}} H_{\delta_1 \delta_2}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(\lambda_W^{(\ell+1)} \right)^2 \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} \langle z_{\delta_5} \sigma'_{\delta_1} \sigma_{\delta_3} \rangle_{G^{(\ell)}} \langle z_{\delta_6} \sigma'_{\delta_2} \sigma_{\delta_4} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_5 \delta_7} G_{(\ell)}^{\delta_6 \delta_8} F_{\delta_7 \delta_1 \delta_8 \delta_2}^{(\ell)} \\
 & + C_W^{(\ell+1)} \lambda_W^{(\ell+1)} \langle \sigma'_{\delta_1} \sigma''_{\delta_2} \sigma_{\delta_3} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} H_{\delta_2 \delta_1}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) C_W^{(\ell+1)} \lambda_W^{(\ell+1)} H_{\delta_2 \delta_4}^{(\ell)} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} \langle z_{\delta_5} \sigma'_{\delta_1} \sigma_{\delta_3} \rangle_{G^{(\ell)}} \langle z_{\delta_6} \sigma''_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_5 \delta_7} G_{(\ell)}^{\delta_6 \delta_8} F_{\delta_7 \delta_1 \delta_8 \delta_2}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) C_W^{(\ell+1)} \lambda_W^{(\ell+1)} \langle \sigma'_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} \left(\langle \sigma''_{\delta_1} \sigma_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_2 \delta_4 \delta_1 \delta_1}^{(\ell)} + \langle \sigma'_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_2 \delta_4 \delta_1 \delta_3}^{(\ell)} \right) \\
 & + C_W^{(\ell+1)} \lambda_W^{(\ell+1)} \langle \sigma'_{\delta_2} \sigma''_{\delta_1} \sigma_{\delta_4} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} H_{\delta_1 \delta_2}^{(\ell)} H_{\delta_1 \delta_3}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) C_W^{(\ell+1)} \lambda_W^{(\ell+1)} H_{\delta_1 \delta_3}^{(\ell)} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} \langle z_{\delta_5} \sigma'_{\delta_2} \sigma_{\delta_4} \rangle_{G^{(\ell)}} \langle z_{\delta_6} \sigma''_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_5 \delta_7} G_{(\ell)}^{\delta_6 \delta_8} F_{\delta_7 \delta_2 \delta_8 \delta_1}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) C_W^{(\ell+1)} \lambda_W^{(\ell+1)} \langle \sigma'_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \left(\langle \sigma''_{\delta_2} \sigma_{\delta_4} \rangle_{G^{(\ell)}} Q_{\delta_1 \delta_3 \delta_2 \delta_2}^{(\ell)} + \langle \sigma'_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} Q_{\delta_1 \delta_3 \delta_2 \delta_4}^{(\ell)} \right) \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 \langle \sigma'_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \langle \sigma'_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} T_{\delta_1 \delta_3 \delta_4 \delta_2}^{(\ell)} \\
 & + \left(C_W^{(\ell+1)} \right)^2 \langle \sigma''_{\delta_1} \sigma''_{\delta_2} \sigma'_{\delta_3} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} H_{\delta_1 \delta_2}^{(\ell)} H_{\delta_1 \delta_3}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 H_{\delta_1 \delta_3}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} \langle z_{\delta_5} \sigma''_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \langle z_{\delta_6} \sigma''_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} G_{(\ell)}^{\delta_5 \delta_7} G_{(\ell)}^{\delta_6 \delta_8} F_{\delta_7 \delta_1 \delta_8 \delta_2}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 H_{\delta_2 \delta_4}^{(\ell)} \langle \sigma'_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \left(\langle \sigma'''_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} Q_{\delta_1 \delta_3 \delta_2 \delta_2}^{(\ell)} + \langle \sigma''_{\delta_2} \sigma''_{\delta_4} \rangle_{G^{(\ell)}} Q_{\delta_1 \delta_3 \delta_2 \delta_4}^{(\ell)} \right) \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \right)^2 H_{\delta_1 \delta_3}^{(\ell)} \langle \sigma'_{\delta_2} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} \left(\langle \sigma'''_{\delta_1} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_2 \delta_4 \delta_1 \delta_1}^{(\ell)} + \langle \sigma''_{\delta_1} \sigma''_{\delta_3} \rangle_{G^{(\ell)}} Q_{\delta_2 \delta_4 \delta_1 \delta_3}^{(\ell)} \right) \\
 & + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.180}$$

张量 $U^{(\ell)}$ 满足如下逐层递推:

$$\begin{aligned}
 U_{\delta_1 \delta_4 \delta_2 \delta_3}^{(\ell+1)} = & \left(C_W^{(\ell+1)} \right)^2 \langle \sigma''_{\delta_1} \sigma''_{\delta_2} \sigma'_{\delta_3} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} H_{\delta_1 \delta_2}^{(\ell)} H_{\delta_1 \delta_3}^{(\ell)} H_{\delta_2 \delta_4}^{(\ell)} \\
 & + \left(\frac{n_\ell}{n_{\ell-1}} \right) \left(C_W^{(\ell+1)} \langle \sigma'_{\delta_1} \sigma'_{\delta_4} \rangle_{G^{(\ell)}} \right) \left(C_W^{(\ell+1)} \langle \sigma'_{\delta_2} \sigma'_{\delta_3} \rangle_{G^{(\ell)}} \right) U_{\delta_1 \delta_4 \delta_2 \delta_3}^{(\ell)} + O\left(\frac{1}{n}\right).
 \end{aligned} \tag{\infty.181}$$

第 ε 章

宏观视角下的模型复杂度

按照 1987 年的炒作，神经网络本应是能够从数据中发现特征和模式的智能模型。相比之下，高斯过程不过是平滑装置。高斯过程怎么可能取代神经网络？究竟是神经网络被过度炒作了，还是我们低估了平滑方法的力量？

David MacKay [71].

本书始终聚焦于既非常宽、又非常深的深度学习模型。之所以如此，是因为这类拥有极多模型参数的大型神经网络在实践中表现极佳，因而构成了现代人工智能方法的基础。

这些模型的参数远多于训练数据，即所谓的**过参数化**模型；它们取得的成功使许多人干脆猜想，在深度学习中“越多越好”。更细致地说，越来越多的经验证据表明，**标度假设**可以准确刻画深度神经网络的行为，而相应的标度律总体上指向过参数化区间的最优性。²⁷⁵ 这些经验规律的简洁性令人想起统计物理学的一个早期时期：当时人们曾猜想，类似的标度假设支配着统计力学中某些复杂系统的行为。²⁷⁶

然而，过参数化模型在深度学习中的实际成功，似乎与正统的机器学习观念和经典统计理论相冲突。启发式地说，奥卡姆剃刀的稀疏性原则主张，我们应当偏爱能够解释观测的最简单假设：在机器学习语境中，这通常被理解为，在比较完成同一任务的模型时，应当优先选择参数较少的模型。更定量地说，我们预期参数较少的模型具有更小的泛化误差， $\mathcal{E} \equiv \mathcal{L}_B - \mathcal{L}_A$ ，并且不易对其训练集 $\mathcal{A}$ 过拟合。反过来，我们会朴素地预期过参数化模型必然过拟合训练数据，因而泛化很差。因此，这一正统观念与过参数化神经网络的经验成功直接冲突，并构成了理解现代深度学习的一大理论谜题。²⁷⁷

在这篇简短的结语中，我们将给出这一谜题的解答。问题的关键取决于**模型复杂度**这一概念。一方面，上述关于泛化的正统讨论采取了**微观视角**——关注网络如何依靠其显式的低层组成部分工作——并试图将模型复杂度等同于模型参数。另一方面，本书把模型参数积掉，发展出一种**宏观视角**——为现实中充分训练网络的预测提供有效理论

²⁷⁵例如，[72] 对基于 Transformer 架构的深度学习语言模型中的标度律进行了经验研究。经验观察表明，过参数化是有益的；训练样本数 N_A 的最优增长速度次线性于参数数目 P 的增长，不过重要的是二者仍应按幂律共同缩放： $N_A \propto P^\alpha$ ，其中 $0 < \alpha < 1$ 。

²⁷⁶在物理学中，这类标度律是普适性现象的一个例子：当系统包含许多基本组成部分时，往往可以用一种不依赖底层系统微观细节的、非常简单的有效理论来描述它 [49]。重整化群框架通过刻画从微观到宏观的流动，进而解释这种普适性如何涌现 [38, 39]。这或许暗示，类似的表征群流概念（参见 §4.6）可能解释 [72] 中的神经标度律。

²⁷⁷例如，[73] 广泛讨论了这样一种困难：试图根据传统的模型复杂度度量来理解大型神经网络为何能如此良好地泛化。

描述——而在这种视角下，模型复杂度的概念被完全颠倒了。

事实上，我们在 §0 中阐述有效理论方法的动机时，所依据的正是这样一种想法：在模型参数数目很大的极限下，我们将能够找到简洁性；从 §1 到 §∞，我们如今已经看到，对于现实的大而有限宽网络，这一假设如何一次又一次得到验证。至此，所有技术计算（附录除外）均已完成；现在可以看出，控制过参数化神经网络模型复杂度的是深宽纵横比

$$r \equiv L/n, \quad (\varepsilon.1)$$

为了理解原因，请回想一下：这个比值在我们的计算中作为有效理论的展开参数或截断尺度出现，并决定了我们如何截断充分训练分布的级数展开，同时仍以最小误差近似网络的真实行为。这意味着，最终定义深度学习中模型复杂度的是截断后近高斯分布中依赖数据的耦合数目，而不是模型参数的数目。从这种宏观视角看，理论中奥卡姆剃刀的稀疏直觉与实践中标度假设的简洁性之间完全不存在冲突。

为了更细致地理解这一点，让我们回顾本书开篇 §0.2 讨论的三个主要问题，然后检视稀疏性原则如何使我们能够解决它们。²⁷⁸ 将训练后的网络输出在网络初始化附近作 Taylor 展开 (0.5)，

$$z(x_\delta; \theta^*) = z(x_\delta; \theta) + \sum_{\mu=1}^P (\theta^* - \theta)_\mu \frac{dz_\delta}{d\theta_\mu} + \frac{1}{2} \sum_{\mu, \nu=1}^P (\theta^* - \theta)_\mu (\theta^* - \theta)_\nu \frac{d^2 z_\delta}{d\theta_\mu d\theta_\nu} + \dots, \quad (\varepsilon.2)$$

我们由此说明了**问题 1** (0.6)：我们可能不得不计算无穷多项，

$$z, \quad \frac{dz}{d\theta}, \quad \frac{d^2 z}{d\theta^2}, \quad \frac{d^3 z}{d\theta^3}, \quad \frac{d^4 z}{d\theta^4}, \quad \dots, \quad (\varepsilon.3)$$

问题 2 (0.7)：我们必须确定从模型参数上的初始化分布到网络输出及其导数上的诱导初始化分布之映射，

$$p(\theta) \rightarrow p\left(z, \frac{dz}{d\theta}, \frac{d^2 z}{d\theta^2}, \dots\right), \quad (\varepsilon.4)$$

以及**问题 3** (0.8)：我们必须求解可能依赖一切的训练动力学，

$$\theta^* \equiv [\theta^*] \left(\theta, z, \frac{dz}{d\theta}, \frac{d^2 z}{d\theta^2}, \dots; \text{learning algorithm; training data} \right). \quad (\varepsilon.5)$$

现在，让我们详细给出这组问题的解答——扩展我们在 §0.2 中给出的示意性说明——然后通过模型复杂度的视角仔细审视这些解答。我们先从简单的无限宽极限开始，再讨论近于简单、却又符合现实的 $1/n$ 截断。

无限宽下的稀疏性

在无限宽极限下，现在可以如下理解我们的解答：

²⁷⁸ 在本结语中，为了简化记号，我们将省略变量的层指标，因为所有量都在输出层求值；当神经元指标不重要时，我们有时也会将其省略。

- 对于**问题 1** (0.11)，所有高阶导数项都消失了，我们只需追踪两个统计变量：

$$z, \frac{dz}{d\theta} \implies z_\delta, \hat{H}_{\delta_1\delta_2}. \quad (\varepsilon.6)$$

注意，这个一阶导数给出了线性模型描述中的随机特征，参见 (10.138)；与这些特征相联系的核心正是 NTK.

- 对于**问题 2**，我们发现网络输出与其一阶导数在统计上相互独立，并且二者分别由简单分布 (0.12) 支配：

$$\lim_{n \rightarrow \infty} p\left(z, \frac{dz}{d\theta}, \frac{d^2z}{d\theta^2}, \dots\right) = p(z_\delta) \delta\left(\sum_{\mu,\nu} \lambda_{\mu\nu} \frac{dz_{\delta_1}}{d\theta_\mu} \frac{dz_{\delta_2}}{d\theta_\nu} - \Theta_{\delta_1\delta_2}\right), \quad (\varepsilon.7)$$

在等式右边， $p(z_\delta)$ 是零均值高斯分布，其方差由核 $K_{\delta_1\delta_2}$ (4.106) 给出；第二个因子是一个 Dirac delta 函数分布，它把构成 NTK $\hat{H}_{\delta_1\delta_2}$ 的一阶导数缩并确定性地固定为冻结 NTK $\Theta_{\delta_1\delta_2}$ (9.4).

- 对于**问题 3**，我们得到了训练后模型参数 θ^* 的闭式解 (0.13)：

$$\lim_{n \rightarrow \infty} \theta_\mu^* = \theta_\mu(t=0) - \sum_{\nu, \tilde{\alpha}_1, \tilde{\alpha}_2, i} \lambda_{\mu\nu} \frac{dz_{i;\tilde{\alpha}_1}}{d\theta_\nu} \tilde{\Theta}^{\tilde{\alpha}_1\tilde{\alpha}_2}(z_{i;\tilde{\alpha}_2} - y_{i;\tilde{\alpha}_2}), \quad (\varepsilon.8)$$

相应的充分训练网络输出 $z_\delta(T) = z(x_\delta; \theta^*)$ 由 (10.31) 给出. 我们还在 §10.2.2 中证明，这个充分训练解与用于训练网络的算法无关.

综合这些认识，我们发现充分训练分布

$$\lim_{n \rightarrow \infty} p\left(z(T)\right) \equiv p\left(z(T) \middle| y_{\tilde{\alpha}}, K_{\delta_1\delta_2}, \Theta_{\delta_1\delta_2}\right), \quad (\varepsilon.9)$$

是一个高斯分布. 之所以用这种方式把它写成条件分布，是因为其均值 (10.40) 只取决于训练集标签向量 $y_{\tilde{\alpha}}$ 和冻结 NTK 矩阵 $\Theta_{\delta_1\delta_2}^{(L)}$ ，而其方差 (10.41) 只取决于核矩阵 $K_{\delta_1\delta_2}^{(L)}$ 和冻结 NTK 矩阵 $\Theta_{\delta_1\delta_2}^{(L)}$.

换言之，测试样本 $x_{\tilde{\beta}}$ 上的预测分布将同时依赖该测试样本与全部训练数据，即 $\mathcal{D} = \{\tilde{\beta}\} \cup \mathcal{A}$ ；这种数据依赖性的形状由依赖数据的耦合的具体函数形式支配，也就是输出层核 $K(x_{\delta_1}, x_{\delta_2})$ 和输出层冻结 NTK $\Theta(x_{\delta_1}, x_{\delta_2})$. 因此，无限宽解 (ε.9) 给出了一种非常稀疏的描述：它仅以简单方式依赖少数几个对象.

有限宽下的近稀疏性

类似地，在大而有限宽的情形下，现在可以如下理解我们的解答：

- 对于**问题 1** (0.16)，当 $k \geq 4$ 时，所有导数 $d^k f/d\theta^k$ 都是 $O(1/n^2)$ ，因此我们只需追踪至多三阶导数的统计变量：

$$z, \frac{dz}{d\theta}, \frac{d^2z}{d\theta^2}, \frac{d^3z}{d\theta^3} \implies z_\delta, \hat{H}_{\delta_1\delta_2}, \widehat{dH}_{\delta_0\delta_1\delta_2}, \widehat{dd_I H}_{\delta_0\delta_1\delta_2\delta_3}, \widehat{dd_{II} H}_{\delta_1\delta_2\delta_3\delta_4}. \quad (\varepsilon.10)$$

这里要注意，对于基于梯度的学习更新，NTK、dNTK 和 ddNTK 捕获了 Taylor 展开 (ε.2) 中至多三阶导数的所有项，参见 (∞.4)、(∞.6) 和 (∞.9).

- 对于**问题 2** (0.17)，我们计算了所有这些统计变量的分布，并发现其联合分布是近高斯的：

$$p\left(z, \frac{dz}{d\theta}, \frac{d^2z}{d\theta^2}, \dots\right) = p\left(z, \widehat{H}, \widehat{dH}, \widehat{dd_I H}, \widehat{dd_{II} H}\right) + O\left(\frac{1}{n^2}\right). \quad (\varepsilon.11)$$

- 对于**问题 3** (0.18)，我们能够利用微扰理论求解非线性训练动力学，并计算有限宽下充分训练网络的预测：

$$z(x_\delta; \theta^*) = [z(x_\delta; \theta^*)] \left(z, \widehat{H}, \widehat{dH}, \widehat{dd_I H}, \widehat{dd_{II} H}; \text{algorithm projectors} \right). \quad (\varepsilon.12)$$

这里，预测的算法依赖性细节是显式的，并完全由少数几个算法投影算子捕获，参见 (∞.142)–(∞.147).

综合这些认识，我们发现充分训练分布

$$p\left(z(T)\right) \equiv p\left(z(T) \middle| y, G, H, V, A, B, D, F, P, Q, R, S, T, U\right) + O\left(\frac{1}{n^2}\right), \quad (\varepsilon.13)$$

是一个近高斯分布；其统计性质完全由这里列出的条件变量描述，不过为了把它们全部写在一行中，我们省略了样本指标。²⁷⁹

除了度量 G 与 NTK 均值 H 之外，这个条件分布还计入了由下列分解产生的有限宽依赖数据的耦合：预激活四点连通相关函数 $\mathbb{E}[zzzz]_{\text{connected}}$ (4.77)、NTK–预激活交叉相关函数 $\mathbb{E}[\widehat{\Delta H}zz]$ (8.67)、NTK 方差 $\mathbb{E}[\widehat{\Delta H}^2]$ (8.82)、dNTK–预激活交叉相关函数 $\mathbb{E}[\widehat{dH}z]$ (11.45)，以及 ddNTK 的均值 $\mathbb{E}[\widehat{dd_I H}]$ 和 $\mathbb{E}[\widehat{dd_{II} H}]$ (∞.11)、(∞.12).

重要的是，所有这些 $O(1/n)$ 阶的有限宽张量都恰好是四个输入样本的函数。例如，对于四点顶角，有 $V_{(\delta_1\delta_2)(\delta_3\delta_4)} \equiv V(x_{\delta_1}, x_{\delta_2}, x_{\delta_3}, x_{\delta_4})$ ；这些依赖数据的耦合的具体函数形式决定了分布的整体数据依赖性。因此，尽管它比无限宽描述 (ε.9) 稍复杂一些，截断至 $O(1/n)$ 的解 (ε.13) 仍是一种近稀疏描述：它仅以近于简单的方式依赖屈指可数的对象。

充分训练神经网络的模型复杂度

有效理论结果 (ε.9) 和 (ε.13) 清楚表明：对于过参数化神经网络，不应再把模型参数的数目等同于模型复杂度。考虑一个训练集与测试集的固定并集，其大小为 N_D ：

- 对于描述充分训练无限宽网络系统的高斯分布 (ε.9)，只需要

$$n_{\text{out}} N_A + \left\lceil \frac{N_D(N_D + 1)}{2} \right\rceil + \left\lceil \frac{N_D(N_D + 1)}{2} \right\rceil = O(N_D^2) \quad (\varepsilon.14)$$

个数就能完全指定该分布；三项分别对应枚举 $y_{i;\tilde{\alpha}}$ 、 $K_{\delta_1\delta_2}$ 和 $\Theta_{\delta_1\delta_2}$ 所需的数目。

²⁷⁹ 还要注意，在这个条件分布中我们也省略了算法投影算子，并假定所考虑的是一个固定的学习算法：算法一旦固定，投影算子只能是含有 $O(1)$ 项的训练集张量——即仅在训练集上计算的度量子矩阵 $\tilde{G}_{\tilde{\alpha}_1\tilde{\alpha}_2}$ 和 NTK 均值子矩阵 $\tilde{H}_{\tilde{\alpha}_1\tilde{\alpha}_2}$ ——以及全局学习率 η 的固定函数；对于梯度下降，例如参见 (∞.142)–(∞.147)。因此，算法依赖性已经完全由我们所条件化的这些张量处理了。

- 对于描述深宽比小而非零、即 $0 < r \ll 1$ 的充分训练有限宽网络系统的近高斯分布 (ε.13)，现在需要

$$O(N_D^4) \quad (\varepsilon.15)$$

个数才能完全指定该分布；计数由有限宽张量主导，而每个张量恰有四个样本指标。

因此，尽管每个无限宽网络都有无限多个微观模型参数，其宏观依赖数据耦合却只随样本数二次增长。有限宽网络的模型参数少于无限宽网络——即有限 < 无限——但宏观有效描述反而更复杂！这正是**微观-宏观对偶性**的体现：参数空间中的复杂性转化为样本空间中的简洁性，模型参数的稠密性交换为依赖数据耦合的稀疏性。在过参数化区间，这种对偶性表明，应当把模型复杂度等同于依赖数据的耦合，而不是模型参数。

为了进一步阐明这一观点，可以设想把有限宽 $1/n$ 展开 (0.15) 推进到更高阶：

$$p(z(T)) = p^{\{0\}}(z(T)) + \frac{p^{\{1\}}(z(T))}{n} + \frac{p^{\{2\}}(z(T))}{n^2} + O\left(\frac{1}{n^3}\right). \quad (\varepsilon.16)$$

首先，此时初始化处的预激活分布

$$p(z|\mathcal{D}) = \frac{1}{Z} e^{-S(z)} + O\left(\frac{1}{n^3}\right), \quad (\varepsilon.17)$$

将由一个六次作用量有效描述：

$$\begin{aligned} S(z) \equiv & \frac{1}{2} \sum_{i=1}^{n_L} \sum_{\delta_1, \delta_2 \in \mathcal{D}} g^{\delta_1 \delta_2} z_{i; \delta_1} z_{i; \delta_2} \\ & - \frac{1}{8} \sum_{i_1, i_2=1}^{n_L} \sum_{\delta_1, \dots, \delta_4 \in \mathcal{D}} v^{(\delta_1 \delta_2)(\delta_3 \delta_4)} z_{i_1; \delta_1} z_{i_1; \delta_2} z_{i_2; \delta_3} z_{i_2; \delta_4} \\ & + \frac{1}{24} \sum_{i_1, i_2, i_3=1}^{n_L} \sum_{\delta_1, \dots, \delta_6 \in \mathcal{D}} u^{(\delta_1 \delta_2)(\delta_3 \delta_4)(\delta_5 \delta_6)} z_{i_1; \delta_1} z_{i_1; \delta_2} z_{i_2; \delta_3} z_{i_2; \delta_4} z_{i_3; \delta_5} z_{i_3; \delta_6}. \end{aligned} \quad (\varepsilon.18)$$

其中六次耦合按

$$u^{(\delta_1 \delta_2)(\delta_3 \delta_4)(\delta_5 \delta_6)} = O\left(\frac{1}{n^2}\right), \quad (\varepsilon.19)$$

缩放，并产生由六点顶角 $U_{(\delta_1 \delta_2)(\delta_3 \delta_4)(\delta_5 \delta_6)}$ 刻画的非平凡连通六点相关函数。²⁸⁰ 在临界性处，这个连通相关函数按

$$\frac{1}{n^2} U_{(\delta_1 \delta_2)(\delta_3 \delta_4)(\delta_5 \delta_6)} \propto O\left(\frac{L^2}{n^2}\right), \quad (\varepsilon.22)$$

²⁸⁰我们在 §4.2 的脚注 44 中计算了第二层的这个顶角；本书还给出了把高阶相关函数计算推广到更深层并分析其临界标度所需的一切。作为检验代数的检查点，对于 ReLU 激活函数，六点顶角的单输入递推为

$$U^{(\ell+1)} = \frac{1}{8} \left[C_W^{(\ell+1)} \right]^3 \left[U^{(\ell)} + 30 V^{(\ell)} K^{(\ell)} + 44 \left(K^{(\ell)} \right)^3 \right], \quad (\varepsilon.20)$$

其临界解为

$$\frac{U^{(\ell)}}{n^2 \left(K^{(\ell)} \right)^3} = 75 \frac{\ell^2}{n^2} + \dots \quad (\varepsilon.21)$$

缩放，与有效理论截断尺度的预期一致。因此，精细化描述 (ε.16) 精确到 L^2/n^2 阶，但代价是模型复杂度显著增加：计数由 $1/n^2$ 阶、各有六个样本指标的有限宽张量主导，需要

$$O(N_D^6) \quad (\varepsilon.23)$$

个数来指定该分布的全部依赖数据耦合。

一般而言，为达到 L^k/n^k 阶精度，宏观描述

$$p(z(T)) = \sum_{m=0}^k \frac{p^{\{m\}}(z(T))}{n^m} + O\left(\frac{L^{k+1}}{n^{k+1}}\right), \quad (\varepsilon.24)$$

的模型复杂度由带有 $2k$ 个样本指标的依赖数据耦合主导，需要

$$O(N_D^{2k}) \quad (\varepsilon.25)$$

个数。这样， $1/n$ 展开给出一列以复杂度增加换取精度提高的有效理论。²⁸¹

重要的是，对于任意特定网络架构，随着深宽比 $r \equiv L/n$ 增大，原则上必须纳入越来越多的高阶项，使宏观有效理论越来越复杂：

- 严格极限 $r \rightarrow 0$ 下，神经元间相互作用关闭，无限宽极限的稀疏 $O(N_D^2)$ 高斯描述 (ε.9) 是准确的。这类网络并不真正深，因为 $L/n = 0$ ；它们也不学习表征 (§10.4.3)。
- 在 $0 < r \ll 1$ 区间，神经元间存在小而非凡的相互作用；截断至 $1/n$ 阶的有限宽有效理论给出的近稀疏 $O(N_D^4)$ 近高斯描述 (ε.13) 是准确的。这类网络既宽、又有非凡深度 $L/n \neq 0$ ，并且学习表征 (§11.4.3)。
- 对于更大的 r ，神经元强耦合，原则上需要更一般的 $O(N_D^{2k})$ 非高斯描述 (ε.24)。然而，此时宏观视角给出无法处理的无效描述；相应地，我们也不预期这种网络对机器学习任务有实际用途 (§3.4)。²⁸²

²⁸¹这里的计数针对训练集与测试集的并集 $\mathcal{D} = \mathcal{A} \cup \mathcal{B}$ ，而非仅训练集 $\mathcal{A}$ ；测试样本 x_{β} 上的随机预测必然依赖该样本。每当预测一个此前未见的新样本时， $N_{\mathcal{D}}$ 和整个数据集 $\mathcal{D}$ 上联合分布 (ε.9)、(ε.13) 的描述都会增大。这种模型称为**非参数模型**，因为完整分布的“参数”——即依赖数据耦合——依赖甚至尚未见过的数据点。

从宏观视角看，任意单次预测的描述随训练集大小按 $O((N_{\mathcal{A}} + 1)^p) \approx O(N_{\mathcal{A}}^p)$ 缩放；原则上可把 x_{β} 代入 (∞.154) 一类预测公式。从微观视角看，若针对训练集 $\mathcal{A}$ 找到模型参数解 $\theta^* \equiv \theta^*(\mathcal{A})$ ，实践中便可忘掉训练集，按 $z(x_{\beta}; \theta^*)$ 作预测，只支付模型预测的计算复杂度。因而，宏观模型复杂度随测试集大小的非参数增长，可视类似于新预测前向传播的微观 $O(P)$ 复杂度。

至少为了理解本结语的题词，也许应当说明：基于高斯分布的非参数模型称为**高斯过程**，所以人们有时称无限宽极限下的神经网络为高斯过程。类似地，有限宽网络上的分布可称为**近高斯过程**。这些过程是函数 $z(x)$ 上的分布，例如 z 是训练后模型的输出函数。我们此前没有引入这种术语，是因为对任意固定数据集 $\mathcal{D}$ ，无需考虑函数上的分布，只需考虑在数据集上求值得有限输出集合的联合分布。

²⁸²在 §3.4 中，我们曾在深线性网络这一特殊情形下进入该区间。即使网络被调到临界性，高阶连通相关函数仍可能不受控制地增长；没有理由预期非线性激活函数会更有利。此外，正如 §5.4 所讨论的，对任意激活函数，高阶相关函数的增长都会导致不同实例间出现巨大涨落，使系综描述 (ε.24) 对任何特定

由此，有效理论截断尺度 r 控制忠实描述不同神经网络行为所需统计量的模型复杂度。宏观视角的简洁性只在截断尺度 r 较小时涌现。

因此，深度学习在过参数化区间的实际成功和简单标度假设的经验准确性告诉我们：有用的神经网络应当稀疏——所以偏爱越来越大的模型——但不能过于稀疏——所以还必须足够深。从宏观视角看，**近稀疏**的模型复杂度或许是深度学习最重要的归纳偏置。



若希望从信息论角度估计深宽比 r^* ，使得宽度对简洁性的吸引力与深度对复杂性的需求取得平衡，最终达到近稀疏性，请尽管翻过这一页，前往附录 A。

网络都不再可信。因而，需要大样本空间复杂度、即大 k 下 $O(N_D^{2k})$ 的深宽比 r 网络通常呈现强耦合混沌；我们不预期它们能被有效描述或实际训练。

即便能找到复杂度如此之大的可用网络，我们真的需要它吗？作为思想模型，考虑几乎不截断的无效描述，例如 $k \sim N_D$ ，它带有指数多个依赖数据耦合 $O(N_D^{N_D})$ 。这种描述只适合无结构数据：例如，若二元标记 $f(x) = \{0, 1\}$ 的每个标签随机选择，则 N_D 个不相关数据点上可能的函数数目为 2^{N_D} ；每加入一个新的输入-输出对，描述复杂度就必须翻倍。这种无结构数据违背机器学习的主要目的之一：识别数据中的模式——即相关性——以学习表征并找到稀疏描述。无结构数据集无法高效学习——例如参见 [74, 75] 的没有免费午餐定理——所以现实机器学习情景不可能需要这种无效描述。

第 A 章

深度学习中的信息

我们能够向任何物理理论提出什么要求？... 自然是一个困难的问题，但对人类心智而言并非奥秘。

Ludwig Boltzmann [76].

在初始化 (§0) 中，我们从理论物理学的视角介绍了理解神经网络的有效理论方法。具体而言，我们讨论了热力学如何被用来阐明蒸汽机等人造机器的行为，随后又说明统计力学如何发展起来，以解释这些宏观定律怎样从大量微观组分的统计行为中涌现。基于这一视角，我们提出，可以把类似框架应用于深度学习理论这一困难问题；如今，从预训练到训练的终点，即从 §1 到 § ∞ ，我们已经揭开了它的神秘面纱。

在第一个附录中，我们将更细致地建立深度学习与这些物理学领域之间的联系。为此，我们会用**信息论**的语言重新表述先前的一些结果。信息论最初由 Shannon 建立，用于定量理解数字通信；它比统计力学晚约半个世纪发展起来，是最契合数字信息时代的统计微观理论。

尽管统计力学与信息论先验地研究截然不同的对象，二者却共享同一种语言，并最终聚焦于同一个基本概念：熵。一种格外优美的熵的组织方式定义了互信息；这是一个正量，可用于刻画对一个可观测量的测量能够在多大程度上为我们提供关于另一个可观测量的信息。它由此给出了定量衡量随机变量相互作用所导致的总体统计依赖性的优美方法。因而，本附录第一节 (§A.1) 将自足地介绍熵与互信息，并着重指出统计力学这一高度物理、模拟式的背景与信息论这一高度抽象、数字式的世界之间的联系。

借助这些新工具，我们将能进一步理解深度学习中的信息。具体而言，对于无限宽神经网络 (§A.2)，我们会从新的角度理解同一层内神经元之间为何没有相互作用，以及临界性为何是深层网络保存区分输入样本所必需信息的必要条件。随后，在有限宽情形 (§A.3) 下，我们将利用变分原理说明：近高斯分布的最大熵原理使我们只需知道截断至 $1/n$ 阶的有效第 ℓ 层预激活量分布，就能把熵与信息量计算到 $1/n^3$ 阶。

在 $1/n^2$ 阶，我们将看到一层中不同神经元组之间存在随深度二次增长的非零互信息；这进一步量化了有限宽下神经元之间的相互作用，并为 §6.4.1 的 Hebb 学习结果给出信息论解释和推广。

在 $1/n^3$ 阶，我们将说明如何选择深宽比 $r \equiv L/n$ ，使互信息作为激活函数的泛函达到最大。这一最优深宽比 r^* 源自一个无监督学习目标，并定义了依赖激活函数的尺度，把表现良好的有效深网络与不再可训练的过深网络分隔开来。

同样在 $1/n^3$ 阶，把互信息推广到三组神经元后，我们将看到有限宽层中的信息以

冗余方式存储于神经元之间. 这一分析使我们能够理解来自输入的信息如何由更深层的神经元表征并在它们之间共享, 从而为 RG 流的粗粒化机制提供新的视角.

最后需要说明, 尽管这里给出的大多数计算都聚焦于预激活量的先验分布, 以研究网络架构与激活函数的归纳偏置, 但这些信息论工具也自然适用于本书讨论过的各种联合分布、贝叶斯后验分布以及充分训练网络的复杂分布. 尚有许多量有待计算; 因此, 我们希望本章能提供一套有用的新工具, 帮助你进一步理解深度学习. 在第二个也是最后一个附录 (§B) 中, 我们将给出一个残差例子, 在残差网络背景下展示这一点.

A.1 熵与互信息

本节将非常简要地概述熵与互信息的概念; 它们在统计力学 [77] 与信息论 [78, 79] 中都发挥着至关重要的作用.

先从服从概率分布 $p(x)$ 的离散随机变量 $x \in \mathcal{X}$ 开始. 在这里, 可以把 x 视为某个特定的可观测结果, 把 $\mathcal{X}$ 视为所有可能结果的集合. **熵** 定义为

$$\mathcal{S}[p(x)] \equiv - \sum_{x \in \mathcal{X}} p(x) \log p(x), \quad (\text{A.1})$$

它是分布的一个泛函: 输入一个分布, 输出一个数. 因而, 应当把熵理解为整个概率分布的性质.

为了直观理解这个量为何有用, 考察它的两个极端. 首先, 当分布完全有序时, 即 $p(x) = \delta_{xx'}$, 使得某个特定结果 $x' \in \mathcal{X}$ 以绝对确定性满足 $p(x') = 1$, 而其余结果的概率都为零, 此时熵取最小值:

$$\mathcal{S}[p(x)] = - \sum_{x \in \mathcal{X}} \delta_{xx'} \log(\delta_{xx'}) = 0, \quad (\text{A.2})$$

因为 x' 贡献 $1 \log(1) = 0$, 其余 x 值则贡献 $0 \log(0) = 0$. 其次, 当分布完全无序时, 即 $p(x) = 1/|\mathcal{X}|$, 所有可能结果 x 均匀分布, 没有哪个结果比其他结果更有可能, 此时熵取最大值:

$$\mathcal{S}[p(x)] = - \sum_{x \in \mathcal{X}} \frac{1}{|\mathcal{X}|} \log\left(\frac{1}{|\mathcal{X}|}\right) = \log(|\mathcal{X}|). \quad (\text{A.3})$$

因此, 在物理学中, 熵通常被视为由随机变量 x 描述的系统之**无序度**.²⁸³ 在这个每种

²⁸³既然我们现在戴着物理学家的帽子, 就应当对熵的单位作一则(无)序之评. 正如 §1.3 脚注 16 中关于量纲分析的讨论, 概率的对数与作用量具有相同的单位, 并且出于同样的原因必须是无量纲的. 不过, 改变对数的底会改变式 (A.1) 前的乘法常数, 从而改变熵的含义:

- 继续戴着物理学家的帽子时, 我们会采用以 e 为底的自然对数; 这使熵的单位具有一个颇为滑稽的名称: 奈特 (*nat*). (有些物理学家还会把式 (A.1) 乘以 Boltzmann 常数 k_B ; 这对于熵在热力学中的宏观应用很自然, 并使熵的单位成为焦耳每开尔文.)
- 戴上计算机科学家的帽子时——为了预备正文的下一段, 我们现在就戴上它——会采用以 2 为底的对数; 此时单位是二进制数位, 也就是你应该很熟悉的**比特 (bit)**. 这在信息论语境中最为自然, 其中熵 (A.1) 有时称为 *Shannon 熵*. 计算机存储器也以比特为单位, 原因正是熵的状态计数直觉: 能够存储 10^9 bits 的硬盘具有 2^{10^9} 个不同状态; 先验地看, 比特的任意特定排列, 即系统

结果都等可能的最大值情形下，熵还可以解释为系统状态数——即 $\mathcal{X}$ 中不同结果的数目——的一种计数方法，因为它等于这一计数的对数。²⁸⁴

为了获得更多直觉，下面从信息论视角来考察。在熵公式 (A.1) 中，期望内部的量称为**惊奇度**：

$$s(x) \equiv -\log p(x) = \log \left[\frac{1}{p(x)} \right] ; \quad (\text{A.4})$$

对于特定结果 x ，分布 $p(x)$ 量化了观测到 x 的频率或合理性；又因为对数是其自变量的单调函数，所以惊奇度随结果 x 的先验稀有程度增大，进而量化实际观测到某个特定 x 有多么令人惊讶或提供了多少信息。因此，惊奇度也定量衡量了作出这一观测后获得了多少新的**信息**。在所有可能结果 $\mathcal{X}$ 上对惊奇度取平均，便得到熵 (A.1)；所以熵可以理解为作出一次观测时预期获得的惊奇或信息量：

$$\mathcal{S}[p(x)] \equiv \mathbb{E}[s(x)] . \quad (\text{A.5})$$

除了具有各种直观解释，熵还满足若干优美的数学性质。首先，它显然非负：

$$\mathcal{S}[p(x)] \geq 0 . \quad (\text{A.6})$$

这是因为概率的允许范围 $0 \leq p(x) \leq 1$ 蕴含 $-p(x) \log p(x) \geq 0$ ；因此，熵 (A.1) 是非负项之和。此外，当且仅当分布完全有序，即由某个特定结果上的 Kronecker delta 给出时，熵取其最小值并为零 (A.2)。

熵的另一项重要性质，是它对两个随机变量 $x \in \mathcal{X}$ 与 $y \in \mathcal{Y}$ 的可加性：当二者的联合分布因子化为 $p(x, y) = p(x)p(y)$ 、因而统计独立 (1.79) 时，

$$\begin{aligned} \mathcal{S}[p(x, y)] &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x, y) \log p(x, y) \\ &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x)p(y) [\log p(x) + \log p(y)] \\ &= - \sum_{x \in \mathcal{X}} p(x) \log p(x) - \sum_{y \in \mathcal{Y}} p(y) \log p(y) \\ &= \mathcal{S}[p(x)] + \mathcal{S}[p(y)] . \end{aligned} \quad (\text{A.7})$$

的任意特定状态，都具有相同的合理性。

本章将采用自然底 e ；研究高斯分布和近高斯分布的熵时，这一选择也非常自然。

²⁸⁴有限多个状态上的均匀分布与熵的最大值之间的这种联系，是最大熵原理的一个例子，并源自所谓 Laplace 的无差别原理：若没有其他信息，系统处于任意特定状态的所有先验概率都应相等。（正如我们将在 §A.3 中讨论的，当我们确实掌握了一些关于状态的信息时，熵便不再由均匀分布最大化。）

需要注意，无差别原理作为微观统计力学的一项主要假设，被应用于能量（近似）相等的宏观热力学状态；相应的熵 (A.3) 有时称为 *Boltzmann* 熵。相比之下，在统计力学语境中，完全一般的公式 (A.1) 有时称为 *Gibbs* 熵。

最后，对贝叶斯主义者而言，无差别原理提供了一种自然选取先验信念集合的方法；遵循这一原理的先验分布有时称为无信息先验。贝叶斯主义者主观地采用这种先验，虽然部分受到奥卡姆剃刀启发式的驱动，却与贝叶斯因子对奥卡姆剃刀的自动而客观的体现截然不同；可参见 §6.2.2 中关于贝叶斯模型比较的讨论。

直观上, 若两个可观测量相互独立, 那么分别观测它们时预期学到的信息量, 就是每次单独观测所获信息量之和. 对于单个结果概率很小的宏观系统, 这使熵成为实际计算中很有用的量: 独立结果的概率相乘, 会产生越来越小的数; 惊奇度以及熵却只是相加. 可加性 (A.7) 具有非常物理的解释: 熵通常是一个广延量, 即它随系统的自由度数目或微观尺度而缩放. 从熵的状态计数解释来看, 这很合理: 若变量 x 描述一个 1 TB 硬盘可能存储的内容, 而变量 y 独立描述另一个 1 TB 硬盘可能存储的内容, 那么两个硬盘的总存储容量具有可加性, 等于 2 TB. 组合“硬盘”系统的可用状态数等于各个“硬盘”系统状态数之积, 所以它们的熵相加.

然而, 若两个硬盘并不独立, 而是受到约束, 使其中一个镜像另一个, 那么它们的总存储容量便是次可加的, 只等于 1 TB.²⁸⁵ 在这种情况下, 严格约束在硬盘内容之间产生了强相关, 使系统的自由度只有我们朴素估计的一半.

因此, 更一般地说, 对于两个统计上依赖、并受到非零相互作用约束的可观测量, 熵满足一种称为次可加性的性质:

$$\mathcal{S}[p(x, y)] \leq \mathcal{S}[p(x)] + \mathcal{S}[p(y)]. \quad (\text{A.8})$$

换言之, 联合分布 $p(x, y)$ 的熵总是小于或等于边缘分布 $p(x)$ 与 $p(y)$ 的熵之和. 这在物理上同样直观: 若两个随机变量统计依赖, 则观测 x 会传达关于观测 y 时可能出现什么结果的信息; 因此, 在已经知道 x 后, 观测 y 所传达的信息就不如尚不知道 x 时那么多.²⁸⁶

²⁸⁵ 这种配置有一种称为 RAID 1 的实际实现; 其中“RAID”代表廉价磁盘冗余阵列, 通过在两个硬盘之间建立数据冗余来实现容错.

²⁸⁶ 对数学上好奇的读者, 可以把这一直觉化为一个简短证明. 通常的路线是先证明 Jensen 不等式, 再把它应用于一个称为 **Kullback–Leibler (KL) 散度** 的辅助对象.

先陈述并证明 Jensen 不等式. 考虑定义在 N 个元素 $a_{\mu=1, \dots, N}$ 上的离散概率分布, 相应概率为 p_{μ} , 且满足 $\sum_{\mu=1}^N p_{\mu} = 1$. 再考虑凸函数 $f(a)$, 即满足

$$f(\lambda a_1 + (1 - \lambda)a_2) \geq \lambda f(a_1) + (1 - \lambda)f(a_2), \quad (\text{A.9})$$

其中 $\lambda \in [0, 1]$ 任意, a_1 与 a_2 是函数定义域中的任意数. Jensen 不等式断言, 该函数的期望大于或等于函数作用于均值所得的值:

$$\mathbb{E}[f(a)] \geq f(\mathbb{E}[a]). \quad (\text{A.10})$$

可以如下对 N 作归纳证明. 首先, $N = 1$ 时式 (A.10) 显然成立. 然后注意

$$\begin{aligned} \mathbb{E}[f(a)] &\equiv \sum_{\mu=1}^{N+1} p_{\mu} f(a_{\mu}) = p_{N+1} f(a_{N+1}) + (1 - p_{N+1}) \sum_{\mu=1}^N \frac{p_{\mu}}{1 - p_{N+1}} f(a_{\mu}) \\ &\geq p_{N+1} f(a_{N+1}) + (1 - p_{N+1}) f\left(\sum_{\mu=1}^N \frac{p_{\mu}}{1 - p_{N+1}} a_{\mu}\right) \\ &\geq f\left(p_{N+1} a_{N+1} + (1 - p_{N+1}) \sum_{\mu=1}^N \frac{p_{\mu}}{1 - p_{N+1}} a_{\mu}\right) = f(\mathbb{E}[a]), \end{aligned} \quad (\text{A.11})$$

其中, 从第一行到第二行使用了 N 个元素的 Jensen 不等式 (A.10), 从第二行到第三行则使用了函数的凸性 (A.9).

下一步, 对离散变量 $x \in \mathcal{X}$ 的两个不同概率分布 $p(x)$ 与 $q(x)$, 引入二者之间的 KL 散度 (有时也称为

把上述论证倒过来，并将式 (A.8) 左右移项，我们定义两个随机变量之间的**互信息**为：

$$\begin{aligned}\mathcal{I}[p(x, y)] &\equiv \mathcal{S}[p(x)] + \mathcal{S}[p(y)] - \mathcal{S}[p(x, y)] \\ &= \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x, y) \log \left[\frac{p(x, y)}{p(x)p(y)} \right].\end{aligned}\quad (\text{A.14})$$

这是联合概率分布的一个泛函，它给出一种平均度量，衡量对 $x \in \mathcal{X}$ 的一次观测向我们传达了多少关于 $y \in \mathcal{Y}$ 的一次观测的信息，反之亦然。按这种方式重排后可以看出，熵的次可加性 (A.8) 蕴含互信息的非负性，

$$\mathcal{I}[p(x, y)] \geq 0, \quad (\text{A.15})$$

等号成立当且仅当可观测结果的集合 $\mathcal{X}$ 与 $\mathcal{Y}$ 统计独立。²⁸⁷ 因此，联合分布的互信息告诉了我们一些关于产生非平凡相关的相互作用的信息，而这种相关正是统计依赖的标志。我们将在 §A.2 中显式计算无限宽神经网络预激活的互信息，并在 §A.3 中对有限宽神经网络作同样的计算：可以想见，有限宽下神经元之间的相互作用将导致非零互信息。作为进行这些计算前的最后一项准备，我们需要把熵的定义 (A.1) 从离散结果推广到连续随机变量：

$$\mathcal{S}[p(x)] \equiv - \int dx \, p(x) \log p(x) = \mathbb{E}[s(x)]. \quad (\text{A.16})$$

尽管熵仍然是惊奇度的期望 (A.4)，但现在为了求这个期望，我们必须计算积分而非求和。由于过渡到连续情形实际上包含一个物理上很有趣的微妙之处，下面用几段来剖析定义 (A.16)。

首先从数学上理解这个微妙之处。由于随机变量是连续的，我们可以在连续的结果空间 $\mathcal{X}$ 中作从 x 到 $\tilde{x} \equiv \tilde{x}(x)$ 的光滑单调坐标变换。既然这种坐标是任意的，一致性便要求：在区间 $[x_1, x_2]$ 中观测到 x 的概率，应当等于在 $[\tilde{x}(x_1), \tilde{x}(x_2)]$ 中观测到 $\tilde{x}$ 的概率。

相对熵)：

$$KL[p(x) \parallel q(x)] \equiv \sum_{x \in \mathcal{X}} p(x) \log \left[\frac{p(x)}{q(x)} \right] = -\mathcal{S}[p(x)] + \mathcal{S}[p(x), q(x)], \quad (\text{A.12})$$

它是两个分布 $p(x)$ 与 $q(x)$ 的多函数泛函，而且重要的是，它关于函数自变量不对称。这里， $\mathcal{S}[p(x), q(x)] \equiv -\sum_{x \in \mathcal{X}} p(x) \log q(x)$ 是称为交叉熵的非对称量。正如 §10.2.3 的脚注 173 首次提到的，KL 散度是衡量两个不同分布接近程度的非对称度量，并与交叉熵损失 (10.36) 密切相关。

最后，把 Jensen 不等式应用于凸函数 $f(a) = -\log(a)$ ，其中离散元素 $a_\mu = q(x)/p(x)$ ，即可证明 KL 散度非负：

$$KL[p(x) \parallel q(x)] \equiv \sum_{x \in \mathcal{X}} p(x) \log \left[\frac{p(x)}{q(x)} \right] \geq -\log \left[\sum_{x \in \mathcal{X}} p(x) \frac{q(x)}{p(x)} \right] = -\log(1) = 0. \quad (\text{A.13})$$

最后，选择分布 $KL[p(x, y) \parallel p(x)p(y)]$ 。KL 散度的非负性 (A.13) 便蕴含熵的次可加性 (A.8)，从而完成证明。

²⁸⁷ 注意，互信息 (A.14) 也可以看成联合分布 $p(x, y)$ 与边缘分布乘积 $p(x)p(y)$ 之间的 KL 散度 (A.12)。也就是说，互信息 $\mathcal{I}[p(x, y)]$ 告诉我们一个联合分布与独立分布的乘积有多接近；非零互信息则表明存在统计依赖。

写成公式，这意味着

$$p(x_1 < x < x_2) \equiv \int_{x_1}^{x_2} dx p(x) \quad (\text{A.17})$$

必须等于

$$p(\tilde{x}_1 < \tilde{x} < \tilde{x}_2) \equiv \int_{\tilde{x}(x_1)}^{\tilde{x}(x_2)} d\tilde{x} p(\tilde{x}) = \int_{x_1}^{x_2} dx \frac{d\tilde{x}}{dx} p(\tilde{x}(x)), \quad (\text{A.18})$$

其中最后一步使用了积分测度在坐标变换下的标准变换性质。因此，两个分布 $p(\tilde{x})$ 与 $p(x)$ 必须满足

$$p(\tilde{x}(x)) \equiv \frac{dx}{d\tilde{x}} p(x), \quad (\text{A.19})$$

这就是众所周知的单变量概率密度坐标变换公式。那么惊奇度的期望又如何呢？在同一个坐标变换下，熵 (A.16) 为

$$\begin{aligned} \mathcal{S}[p(\tilde{x})] &= - \int d\tilde{x} p(\tilde{x}) \log p(\tilde{x}) \\ &= - \int dx \frac{d\tilde{x}}{dx} \frac{dx}{d\tilde{x}} p(x) \left[\log p(x) + \log \left(\frac{dx}{d\tilde{x}} \right) \right] \\ &= \mathcal{S}[p(x)] + \int dx p(x) \log \left(\frac{d\tilde{x}}{dx} \right), \end{aligned} \quad (\text{A.20})$$

其中第二行再次使用了积分测度在坐标变换下的标准变换性质，还使用式 (A.19) 以旧坐标表示概率分布。所以，在一般的（单调）坐标变换下，只要审慎选择变换的雅可比因子 $d\tilde{x}/dx$ ，我们便可以让熵取任意想要的值，甚至取负值！

现在从物理上理解这个微妙之处。考虑一个仅为乘法因子的坐标变换 $\tilde{x} = cx$ ，这就像把测量可观测量 x 的基本单位从 `inches` 改成 `meters`。此时，每个特定结果的惊奇度都平移同一个常数 $\Delta s(x) = \log c$ ，熵也相应平移。因此，对连续量而言，熵以加法方式依赖于我们测量可观测量时所选的单位；在定义熵 (A.16) 时，我们确实应当同时指定这些单位。²⁸⁸

也许最合理的选择，是按照物理上能够分辨的 x 的最小测量值来设定测量单位，换言之，按照物理世界的约束所设定的精度极限来选择。这个精度极限 ϵ 有时称为截断；在实践中，它意味着我们只关心在 $[x_0, x_0 + \epsilon]$ 之间找到 x 的离散概率。²⁸⁹ 对结果空间作

²⁸⁸对于任何有量纲的可观测量，概率密度 $p(x)$ 也必须有量纲，从而使在区间 $[x_1, x_2]$ 中观测到 x 的概率 $p(x_1 < x < x_2) \equiv \int_{x_1}^{x_2} dx p(x)$ 正确地成为无量纲量。然而，正如我们在脚注 16（见 §1）中讨论过的，把这样一个有量纲对象 $p(x)$ 放入对数的宗量而写成 $\log p(x)$ 是不合法的。这也从另一个角度说明，对于连续概率分布，也就是概率密度，我们需要指定测量单位，才能妥善定义熵。

对于好奇且可能有所担忧的读者，需要指出：包含贝叶斯模型比较中观测依赖性的贝叶斯因子 (6.30)，在观测 y_A 的坐标变换下是不变的。那里最终重要的是不同假设的证据之间的相对大小，而不是各个证据的绝对值。

还请不要把概率密度的单位问题与我们在脚注 283 中讨论的熵的单位混淆：前者以加法常数改变熵，后者则以乘法常数改变熵。注意，对于离散概率分布，概率分布给出的是普通概率，本身已经无量纲；可参见脚注 283 中的简短讨论。

²⁸⁹请不要把这里的测量精度截断与有效理论的微扰截断，即深宽比 $r \equiv L/n$ 混淆。虽然二者都可以视作重要尺度，但物理意义截然不同：在前一种情况下，精度截断给出两个可观测量测量值之间最小的可分辨差异， $\epsilon \equiv \min(|z_2 - z_1|)$ ；在后一种情况下，有效理论的截断 L/n 则设定了预激活分布 $p(z)$ 中必须计入有限宽修正的尺度。

这种离散化，便可保证熵始终为正 (A.6)，因为此时我们又回到了离散概率。²⁹⁰ 如果熵对略显任意的截断具有这种物理敏感性令你感到困扰，那么也许应当考虑互信息的连续版本：

$$\begin{aligned}\mathcal{I}[p(x, y)] &\equiv \mathcal{S}[p(x)] + \mathcal{S}[p(y)] - \mathcal{S}[p(x, y)] \\ &= \int dx dy p(x, y) \log \left[\frac{p(x, y)}{p(x) p(y)} \right],\end{aligned}\quad (\text{A.21})$$

其中，以熵表示的定义与离散情形 (A.14) 相同。特别地，互信息对测量坐标的选择不敏感。为了说明这一点，考虑两个连续随机变量 x 和 y ，以及各自独立的单调坐标变换：

$$p(\tilde{x}(x)) = \frac{dx}{d\tilde{x}} p(x), \quad p(\tilde{y}(y)) = \frac{dy}{d\tilde{y}} p(y), \quad p(\tilde{x}(x), \tilde{y}(y)) = \frac{dx}{d\tilde{x}} \frac{dy}{d\tilde{y}} p(x, y), \quad (\text{A.22})$$

这些关系来自与上文类似的概率一致性论证。据此，现在可以证明互信息 (A.21) 在这些坐标变换下保持不变：

$$\begin{aligned}\mathcal{I}[p(\tilde{x}, \tilde{y})] &\equiv \mathcal{S}[p(\tilde{x})] + \mathcal{S}[p(\tilde{y})] - \mathcal{S}[p(\tilde{x}, \tilde{y})] \\ &= \int d\tilde{x} d\tilde{y} p(\tilde{x}, \tilde{y}) \log \left[\frac{p(\tilde{x}, \tilde{y})}{p(\tilde{x}) p(\tilde{y})} \right] \\ &= \int dx dy p(x, y) \log \left[\frac{p(x, y)}{p(x) p(y)} \right] \equiv \mathcal{I}[p(x, y)].\end{aligned}\quad (\text{A.23})$$

从第二行到第三行，坐标变换因子 $dx/d\tilde{x}$ 与 $dy/d\tilde{y}$ 在对数内部完全相消，而测度的变换又消去了对数外部的坐标变换因子。因此，对连续随机变量而言，互信息是完全良定义的，并且与截断 ϵ 无关。正因如此，只要一致且固定地选取单位，在计算互信息的过程中把熵作为中间步骤来计算就是完全合理的；我们将在后续各节使用这一事实。最后要注意，互信息的概念可以推广到两个以上的随机变量。例如，在 §A.3 中，我们将考虑三个随机变量 $x \in \mathcal{X}$ 、 $y \in \mathcal{Y}$ 与 $z \in \mathcal{Z}$ 之间的三元信息：

$$\begin{aligned}\mathcal{I}_3[p(x, y, z)] & \\ &\equiv \mathcal{I}[p(x, y)] - \mathcal{I}[p(x, y|z)] \\ &= \mathcal{S}[p(x)] + \mathcal{S}[p(y)] + \mathcal{S}[p(z)] - \mathcal{S}[p(x, y)] - \mathcal{S}[p(y, z)] - \mathcal{S}[p(z, x)] + \mathcal{S}[p(x, y, z)] \\ &= \sum_{x \in \mathcal{X}, y \in \mathcal{Y}, z \in \mathcal{Z}} p(x, y, z) \log \left[\frac{p(x, y) p(y, z) p(z, x)}{p(x) p(y) p(z) p(x, y, z)} \right].\end{aligned}\quad (\text{A.24})$$

这里， $\mathcal{I}[p(x, y|z)]$ 是给定 z 后 x 与 y 的联合分布 $p(x, y|z)$ 的互信息； $\mathcal{I}_3[p(x, y, z)]$ 的最后一个表达式清楚表明：(a) 它关于三个自变量完全对称；(b) 可以想见，它的连续版本与截断无关，并且在类似于式 (A.22) 的坐标变换下保持不变。

三元信息可以为正也可以为负，这一点并非立即显然。从式 (A.24) 中的第一个表达式，可以对三元信息的含义获得一些直觉：它衡量对第三个随机变量的了解——在这

²⁹⁰在深度学习的语境中，一个自然选择是网络变量浮点表示的精度极限。由于 `float` 类型顾名思义具有相对于所存储数值的精度，也许可以选取相关范围内的最小精度。

种写法中即 z ——会增加还是减少另外两个变量之间的互信息。当三元信息为正时，这表明 z 包含关于 x 和 y 的信息，因此知道 z 会减少通过测量 y 而了解到的关于 x 的信息量；信息以冗余方式存储在这三个变量之间。当三元信息为负时，这表明信息分布在 x 、 y 与 z 之间，使得仅测量 y 所了解到的关于 x 的信息，比先知道 z 再测量 y 时更少；此时，信息以协同方式存储在这三个变量之间。²⁹¹

A.2 无限宽下的信息：临界性

结束上述信息丰富的引言后，现在让我们用这些抽象定义来更好地理解神经网络先验分布，从而将其具体化。

首先，考虑无限宽神经网络第 ℓ 层的 m 个预激活 $z_{i;\alpha}^{(\ell)}$ 。无论你从正文的哪个位置读到本附录，下面这一点或许已经深植于脑海：这些预激活服从零均值高斯分布

$$p(z_1, \dots, z_m | \mathcal{D}) = \frac{1}{\sqrt{|2\pi K|^m}} \exp\left(-\frac{1}{2} \sum_{i=1}^m \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} K^{\alpha_1 \alpha_2} z_{i;\alpha_1} z_{i;\alpha_2}\right), \quad (\text{A.25})$$

在这个表达式以及本节中，为使表达式简洁，我们将处处省略层指标。于是，该分布的熵 (A.16) 为

$$\begin{aligned} \mathcal{S}[p(z_1, \dots, z_m | \mathcal{D})] &= \left\langle \left\langle \frac{1}{2} \sum_{i=1}^m \sum_{\alpha_1, \alpha_2 \in \mathcal{D}} K^{\alpha_1 \alpha_2} z_{i;\alpha_1} z_{i;\alpha_2} \right\rangle \right\rangle_K + \log\left(\sqrt{|2\pi K|^m}\right) \\ &= \frac{m}{2} (N_{\mathcal{D}} + \log |2\pi K|) = \frac{m}{2} \log |2e\pi K|, \end{aligned} \quad (\text{A.26})$$

提醒一下， $|2\pi eK|$ 是 $N_{\mathcal{D}}$ 乘 $N_{\mathcal{D}}$ 矩阵 $2\pi eK_{\alpha_1 \alpha_2}$ 的行列式。²⁹² 由此可知，熵是广延的，与联合分布 (A.25) 中的神经元数 m 成正比。这表明，在深度学习语境中，熵可以如何计数自由度——在这里是通过计数神经元——而关于神经元数的严格可加性向我们表明，无限宽层中的各个神经元彼此无相互作用且统计独立。为直接证实这一点，我们来计算同一层 ℓ 中两组神经元 $\mathcal{M}_1 = \{1, \dots, m_1\}$ 与 $\mathcal{M}_2 = \{m_1 + 1, \dots, m_1 + m_2\}$ 之间的互

²⁹¹ 正三元信息的一个极端例子是 x 、 y 与 z 完全依赖，并且彼此是完全相同的副本。在这种冗余情形中， $\mathcal{I}[p(x, y)] > 0$ ，因为知道 y 便能获知关于 x 的一切；但 $\mathcal{I}[p(x, y|z)] = 0$ ，因为以 z 为条件后，再观测 y 已经无法让我们进一步了解 x 。这种情形的一个例子是同一本书的三个副本。

负三元信息的一个极端例子是 x 与 y 的联合分布因子化为 $p(x, y) = p(x)p(y)$ ，但以 z 为条件的联合分布并不因子化，即 $p(x, y|z) \neq p(x|z)p(y|z)$ 。在这种协同情形中， $\mathcal{I}[p(x, y)] = 0$ ，因为没有 z 时这些变量统计独立；但 $\mathcal{I}[p(x, y|z)] > 0$ ，因为存在由 z 介导的相关。这种情形的一个例子可以是把一把密钥分发给三个不同参与方的编码：知道任意两部分都完全得不到关于密钥的信息，但把三部分合在一起便能重构密钥。

²⁹² 为方便起见，在本节和下一节中，我们将忽略连续熵定义中的歧义，直接使用公式 (A.16)。这是允许的，因为我们最终关心的是与截断无关的量，例如互信息；而在解释式 (A.26) 这样的熵时，我们永远不会关心其绝对值。

信息. 为把这一平凡结果写得极尽详细, 我们有

$$\begin{aligned} & \mathcal{I} \left[p(\mathcal{M}_1, \mathcal{M}_2 | \mathcal{D}) \right] \\ &= \mathcal{S} \left[p(z_1, \dots, z_{m_1} | \mathcal{D}) \right] + \mathcal{S} \left[p(z_{m_1+1}, \dots, z_{m_1+m_2} | \mathcal{D}) \right] - \mathcal{S} \left[p(z_1, \dots, z_{m_1+m_2} | \mathcal{D}) \right] \\ &= [m_1 + m_2 - (m_1 + m_2)] \frac{1}{2} \log |2e\pi K| = 0. \end{aligned} \quad (\text{A.27})$$

为了得到最后一行, 我们以三种不同方式使用了式 (A.26). 这个为零的互信息证实, 在无限宽下, 获知一层中某些神经元的活动, 并不会提供有关任何其他神经元活动的信息. 若要得到有限的结果, 我们必须退离无限宽极限 (§A.3). 不过, 对于一个固定的神经元, 我们确实预期不同输入之间存在非平凡相关, 因而也存在有限的互信息. 为研究这一点, 取两个输入 $x_{i,+}$ 和 $x_{i,-}$, 并计算某个特定神经元的预激活 $z_{1,+}$ 与 $z_{1,-}$ 之间的互信息. 将熵 (A.26) 代入互信息的定义 (A.14), 可得

$$\begin{aligned} \mathcal{I} [p(z_{1,+}, z_{1,-} | x_{\pm})] &= \frac{1}{2} [\log(K_{++}) + \log(K_{--}) - \log(K_{++}K_{--} - K_{+-}^2)] \\ &= \frac{1}{2} \log \left(\frac{K_{++}K_{--}}{K_{++}K_{--} - K_{+-}^2} \right). \end{aligned} \quad (\text{A.28})$$

现在关注等范数输入 $x_{i,\pm}$, 此时 $K_{++} = K_{--} = K_{[0]} + K_{[2]}$ 且 $K_{+-} = K_{[0]} - K_{[2]}$; 参见式 (5.17) 与式 (5.19). 我们可将此互信息改写为

$$\mathcal{I} [p(z_{1,+}, z_{1,-})] = \frac{1}{2} \log \left[\frac{\left(1 + \frac{K_{[2]}}{K_{[0]}}\right)^2}{4 \frac{K_{[2]}}{K_{[0]}}} \right], \quad (\text{A.29})$$

它完全由无量纲比值 $K_{[2]}/K_{[0]}$ 参数化; 对于邻近输入 $x_{i,\pm} = x_{i,0} \pm \delta x_i/2$, 该比值刻画它们通过网络传播到第 ℓ 层后的相对夹角.

这里有两个值得关注的极限. 第一, 当 $K_{[2]}/K_{[0]} \rightarrow 0$ 时, 互信息变大. 这是因为随着预激活之间的相对夹角消失, 它们会彼此接近: 知道一个输入对应的预激活, 便能告诉我们另一个输入对应的预激活值. 在分类问题中, 如果两个输入属于同一类别, 这是很好的先验; 但如果它们属于不同类别, 就会使学习变得非常困难. 第二, 当 $K_{[0]} = K_{[2]}$ 时, 互信息消失. 这是因为在此极限下, 核的非对角分量 $K_{+-} = K_{[0]} - K_{[2]}$ 消失: 预激活变得统计独立. 在分类问题中, 如果两个输入属于不同类别, 这可能是很好的先验——只要类别的细节不以某种方式相关——但如果它们属于同一类别, 就会使学习变得非常困难. 总之, 这表明作为先验, 我们不希望 $K_{[2]}/K_{[0]}$ 过大或过小; 令 $\chi_{\parallel} = 1$ 和 $\chi_{\perp} = 1$, 便能最好地保证这一点, 参见式 (5.55). 这给出了关于临界性的信息论视角. 最后, 尽管这里一直关注初始化时网络的先验分布, 我们也可以利用贝叶斯后验 (6.66) 或基于梯度学习的充分训练分布 (10.39), 研究学习后的这些相同量. 由于高斯分布的熵与其均值无关——通过改变哑积分变量即可消去均值——任一种训练后无限宽网络的互信息仍由同一表达式 (A.28) 给出, 只需将核替换为贝叶斯后验分布的协方差 (6.57), 或广义后验分布的协方差 (10.41). 在后一种情形中, 互信息将同时涉及核与冻结 NTK; 对它的分析会得到与我们在 §10.3.1 中研究偏差-方差权衡时类似的结果. 这会给出关于泛化的信息论视角.²⁹³

²⁹³类似地, 两类后验中式 (A.28) 的三元信息推广, 可从另一视角说明 §10.3.2 的 *-插值结果.

A.3 有限宽下的信息：最优深宽比

本节将看到，有限宽网络的先验会在不同神经元之间产生非零互信息。如果凭直觉认为非零互信息是可取的——并类比于一个无监督学习目标——就可以利用这一计算来优化临界有限宽 MLP 的深宽比。这一最优深宽比 r^* 定义了一个尺度，将可用我们的有效理论方法描述的有效深网络，与因强相互作用而无法描述、并因大涨落而无法训练的过深网络分隔开来。²⁹⁴ 一般而言，任何相互作用理论的熵与互信息都非常难以计算。不过，当相互作用是近高斯的时，我们可以使用微扰理论。为此，实际上有一个精巧的变分原理可用来组织计算；下面先解释这一原理。

与上一节一样，我们将关注第 ℓ 层中 m 个预激活量的分布，略去（几乎）所有层指标，并且只考察单个输入 x 。正如我们从很久以前 (§1.3) 就一直在做的那样，把概率分布用作用量表示为

$$p(z_1, \dots, z_m | x) = \frac{e^{-S(z_1, \dots, z_m)}}{Z}, \quad (\text{A.30})$$

它必须由配分函数归一化：

$$Z = \int \left[\prod_{i=1}^m dz_i \right] e^{-S(z_1, \dots, z_m)}. \quad (\text{A.31})$$

用这些量，熵 (A.16) 可以表示为

$$\mathcal{S}[p(z_1, \dots, z_m | x)] = \log(Z) + \frac{1}{Z} \int \left[\prod_{i=1}^m dz_i \right] e^{-S(z_1, \dots, z_m)} S(z_1, \dots, z_m). \quad (\text{A.32})$$

请务必不要混淆作用量 $S(z)$ 与熵 $\mathcal{S}[p(z)]$ ：前者是预激活量的函数，后者则是概率分布的泛函。²⁹⁵ 为继续推进，我们采用一个**变分拟设**：把作用量分成两部分，写成

$$S(z_1, \dots, z_m) = S_F(z_1, \dots, z_m) + S_I(z_1, \dots, z_m), \quad (\text{A.33})$$

其思想是第二项 S_I 编码分布中微扰意义下很小的部分。具体而言，**变分原理**要求我们选取式 (A.33) 中的第一项 $S_F(z)$ ，使熵关于 $S_I(z)$ 的变分为零：

$$0 = \left. \frac{\delta \mathcal{S}[p(z)]}{\delta S_I(z)} \right|_{S_I(z)=0}. \quad (\text{A.34})$$

我们很快就会满足这一条件。此外， $S_I(z)$ 不应完全任意，而应恰当地反映预激活量分布 $p(z_1, \dots, z_m | x)$ 的统计性质。第一项约束要求：用变分作用量计算得到的二点相关子应由精确的单输入度量 G 决定：

$$\mathbb{E}[z_{i_1} z_{i_2}] \equiv \delta_{i_1 i_2} G. \quad (\text{A.35})$$

²⁹⁴请注意，在本节寻找宽而有限的一层中 m 个神经元的有效分布时，我们需要使用在 §4.4 中推导的跑动耦合表达式。因此，继续之前重读该节可能会有所帮助。

²⁹⁵若选择预激活量 z 的单位使配分函数为一，即 $Z = 1$ ，则作用量就是惊奇度 (A.4)，因而熵就是作用量的期望： $\mathcal{S}[p(z)] = \mathbb{E}[S(z)]$ 。请注意，在热力学中，常数 $-\log Z$ 有时称为自由能；上述讨论应当说明，只有它在两个不同分布之间的相对值才具有物理意义。

第二项约束要求：用变分作用量计算得到的连通四点相关子应由精确的单输入四点顶点决定：

$$\mathbb{E}[z_{i_1} z_{i_2} z_{i_3} z_{i_4}]|_{\text{connected}} = \frac{1}{n} (\delta_{i_1 i_2} \delta_{i_3 i_4} + \delta_{i_1 i_3} \delta_{i_2 i_4} + \delta_{i_1 i_4} \delta_{i_2 i_3}) V. \quad (\text{A.36})$$

约束 (A.35) 和 (A.36) 将共同固定变分作用量 S_I 的耦合，使完整作用量 (A.33) 正确刻画 m 神经元的预激活量分布 (A.30).²⁹⁶

为理解为何要这样做，请注意，我们的变分原理最终不过是近高斯分布的**最大熵原理**的一种实现。²⁹⁷ 具体来说，首先要注意，高斯分布本身可以推导为在固定一阶矩和二阶矩的约束下使熵 (A.16) 最大的分布。²⁹⁸ 正如马上会看到的，在式 (A.34) 中，我们关于作用量偏离高斯性的形变 S_I 将分布的熵最大化，同时施加约束，在微扰理论中逐阶固定高阶累积量。一般而言，当我们固定了可观测信息并希望求出其底层分布时，最大熵原理是一种合适的处理方法。在这里，我们实际上知道产生 G 和 V 的分布，即式 (A.30)，但仍可把这一原理用作计算熵的便利工具。²⁹⁹ 现在，为满足变分原理 (A.34)，我们选取

$$S_F(z_1, \dots, z_m) = \frac{1}{2G} \sum_{i=1}^m z_i^2. \quad (\text{A.38})$$

重要的是， G 不只是作用量 $S(z)$ 中二次项系数的倒数，而是我们实际测量到的精确二点相关子 (A.35)，其中包含相互作用所致的完整修正级数，参见式 (4.104).³⁰⁰ 为说明这一选取为何满足变分原理，首先把完整分布 (A.30) 下的期望改写成更简单的高斯期望；后者取自具有相同方差 (A.35) 的零均值高斯分布：

$$\langle\langle z_{i_1} z_{i_2} \rangle\rangle_G = \delta_{i_1 i_2} G. \quad (\text{A.39})$$

这里请回顾我们的记号 $\langle\langle \cdot \rangle\rangle_G$ ，它表示方差为 $\delta_{i_1 i_2} G$ 的多神经元函数的高斯期望：

$$\langle\langle f(z_1, \dots, z_m) \rangle\rangle_G \equiv \frac{1}{Z_G} \int \left[\prod_{i=1}^m dz_i \right] e^{-\frac{1}{2G} \sum_{i=1}^m z_i^2} f(z_1, \dots, z_m), \quad (\text{A.40})$$

²⁹⁶原则上还有来自更高点相关子统计性质的额外约束，但它们的贡献相对于我们将要处理的领先阶和次领先阶都是次领先的。

²⁹⁷对于喜欢这些历史旁白的读者，最大熵原理由 Jaynes 发现，它在一方面的信息论与另一方面的统计力学之间建立了联系 [80, 81]。举例来说，考虑统计力学的一个核心问题：求系统基本微观态 i 的概率分布 p_i ，其中系统具有宏观平均能量 $\bar{E} \equiv \mathbb{E}[E_i] = \sum_i p_i E_i$ 。对最大熵原理的应用会正确选出统计力学中的 Boltzmann 分布（有时也称为 Gibbs 分布）：

$$p_i \propto e^{-\beta E_i}, \quad (\text{A.37})$$

只要我们在能量的可观测约束 $\sum_i p_i E_i = \bar{E}$ 和分布的归一化条件 $\sum_i p_i = 1$ 下优化熵 (A.1)。这里， β 是依赖于能量 $\bar{E}$ 的 Lagrange 乘子，其物理解释为逆温度 $\beta = 1/(k_B T)$ ；其中 k_B 是前述 Boltzmann 常数， T 则是大家都熟悉的温度。这个例子还说明了统计力学如何把基本微观态 i 的细节与 $\bar{E}$ 、 T 等宏观热力学变量联系起来。

²⁹⁸给正在逐项记录的读者：未固定任何信息时，最大熵分布是均匀分布，参见式 (A.3)；固定一阶矩时，最大熵分布是 Boltzmann 分布，参见式 (A.37)；固定一阶矩和二阶矩时，最大熵分布是高斯分布，参见（几乎）本书各处。

²⁹⁹具体而言，这一过程将组织熵的微扰计算，并保证我们只需计算式 (A.40) 所示形式的高斯期望。

³⁰⁰这将使我们能够用这些可测量量表示熵，而完全不必实际计算该级数中的任何修正。

还要注意，这样的高斯分布需要另一个配分函数：

$$Z_G \equiv \int \left[\prod_{i=1}^m dz_i \right] e^{-\frac{1}{2G} \sum_{i=1}^m z_i^2} = (2\pi G)^{\frac{m}{2}} ; \quad (\text{A.41})$$

特别地， $Z \neq Z_G$. 接下来，用这些更简单的期望把熵 (A.32) 改写为

$$\begin{aligned} \mathcal{S}[p(z_1, \dots, z_m|x)] &= \log Z + \mathbb{E} \left[\frac{1}{2G} \sum_{i=1}^m z_i^2 \right] + \frac{1}{Z} \int \left[\prod_{i=1}^m dz_i \right] e^{-\frac{1}{2G} \sum_{i=1}^m z_i^2} e^{-S_I} S_I \\ &= \frac{m}{2} \log(2\pi G) + \log \left(\frac{Z}{Z_G} \right) + \frac{m}{2} + \left(\frac{Z}{Z_G} \right)^{-1} \langle e^{-S_I} S_I \rangle_G , \end{aligned} \quad (\text{A.42})$$

其中，第一行等式只代入了式 (A.33)，第二行等式则用式 (A.40) 把所有完整期望改写成更简单的高斯期望. 随后，对 S_I 作 Taylor 展开，可将配分函数之比计算为

$$\begin{aligned} \frac{Z}{Z_G} &= \frac{1}{Z_G} \int \left[\prod_{i=1}^m dz_i \right] e^{-\frac{1}{2G} \sum_{i=1}^m z_i^2} (e^{-S_I}) = \langle e^{-S_I} \rangle_G \\ &= 1 - \langle S_I \rangle_G + \frac{1}{2} \langle S_I^2 \rangle_G - \frac{1}{6} \langle S_I^3 \rangle_G + O(S_I^4) , \end{aligned} \quad (\text{A.43})$$

类似地，所需的高斯期望为

$$\langle e^{-S_I} S_I \rangle_G = \langle S_I \rangle_G - \langle S_I^2 \rangle_G + \frac{1}{2} \langle S_I^3 \rangle_G + O(S_I^4) . \quad (\text{A.44})$$

把这些结果代回熵的变分表达式 (A.42) 并整理各项——此时 $\log(1+x) = x - \frac{x^2}{2} + \frac{x^3}{3} + \dots$ 与 $1/(1+x) = 1 - x + x^2 - x^3 + \dots$ 可能会有所帮助——得到

$$\begin{aligned} \mathcal{S}[p(z_1, \dots, z_m|x)] &= \frac{m}{2} \log(2\pi e G) - \frac{1}{2} [\langle S_I^2 \rangle_G - \langle S_I \rangle_G^2] \\ &\quad + \frac{1}{3} [\langle S_I^3 \rangle_G - 3 \langle S_I^2 \rangle_G \langle S_I \rangle_G + 2 \langle S_I \rangle_G^3] + O(S_I^4) . \end{aligned} \quad (\text{A.45})$$

首先，第一项恰好是协方差为 $\delta_{i_1 i_2} G$ 的多元高斯分布的熵，参见式 (A.26). 其次，也是最重要的一点，原本可能出现的、正比于 $\langle S_I \rangle_G$ 的线性项恰好抵消了. 换言之，作用量分解 (A.33) 的拟设在采用式 (A.38) 的选取后，自动满足变分原理 (A.34).

最后顺便指出，来自二次项的领先修正确定为负.³⁰¹ 这一负性实际上是数学自洽性所必需的：对于任何一组一阶矩和二阶矩已知且固定的随机变量，高斯分布都会使熵最大化，因此任何在遵守这些矩约束的同时使分布偏离高斯性的形变，都必然具有更小的熵. 在当前情形中，我们的变分拟设 (A.33) 给出了零均值高斯分布的近高斯形变.³⁰² 闲话就说到这里；下面满足约束 (A.35) 和 (A.36)，再用变分表达式 (A.45) 计算有限宽网络中预激活量的熵与互信息.

³⁰¹为看清这一点，注意二次项方括号内的表达式就是作用量变分部分的方差，因而为正： $\langle S_I^2 \rangle_G - \langle S_I \rangle_G^2 = \langle (S_I - \langle S_I \rangle_G)^2 \rangle_G \geq 0$.

³⁰²注意：式 (A.45) 中第二组方括号内的各项，是计算次领先阶修正所必需的.

领先阶修正：非零互信息

在领先阶，我们已经知道如何把变分作用量 S_I 的耦合与单输入度量 G 、单输入四点相关子 V 联系起来。回顾在 §4.4 中边缘化神经元时关于跑动耦合的讨论，作用量的领先修正为

$$S_I(z_1, \dots, z_m) = \frac{1}{2} \left(g_m - \frac{1}{G} \right) \sum_{i=1}^m z_i^2 - \frac{v_m}{8} \sum_{i,j=1}^m z_i^2 z_j^2 + O\left(\frac{1}{n^2}\right), \quad (\text{A.46})$$

其中，跑动二次耦合由式 (4.102) 给出：

$$g_m = \frac{1}{G} + \left(\frac{m+2}{2} \right) \frac{V}{nG^3} + O\left(\frac{1}{n^2}\right), \quad (\text{A.47})$$

跑动四次耦合则由式 (4.103) 给出：

$$v_m = \frac{V}{nG^4} + O\left(\frac{1}{n^2}\right). \quad (\text{A.48})$$

为得到式 (A.46)，考察 m 个预激活量的分布表达式 (4.97)，再把式 (A.33) 与 (A.38) 重新整理，解出 S_I 即可。若不记得如何得到式 (A.47) 和 (A.48)，可以翻回 §4.4 的最后一个小小节重读，也可以向后翻到下一小节；在那里，我们必须在 $1/n$ 展开的更高阶重新推导这些表达式，参见式 (A.59) 和 (A.63)。

作用量的领先阶变分修正 S_I (A.46) 现在满足约束 (A.35) 和 (A.36)，因此可以计算熵 (A.45) 的领先修正：

$$\begin{aligned} & \langle\langle S_I^2 \rangle\rangle_G - \langle\langle S_I \rangle\rangle_G^2 \\ &= \frac{1}{4} \left(g_m - \frac{1}{G} \right)^2 \sum_{i_1, i_2=1}^m [\langle\langle z_{i_1}^2 z_{i_2}^2 \rangle\rangle_G - \langle\langle z_{i_1}^2 \rangle\rangle_G \langle\langle z_{i_2}^2 \rangle\rangle_G] \\ & \quad - \frac{1}{8} \left(g_m - \frac{1}{G} \right) v_m \sum_{i_1, i_2, i_3=1}^m [\langle\langle z_{i_1}^2 z_{i_2}^2 z_{i_3}^2 \rangle\rangle_G - \langle\langle z_{i_1}^2 z_{i_2}^2 \rangle\rangle_G \langle\langle z_{i_3}^2 \rangle\rangle_G] \\ & \quad + \frac{1}{64} v_m^2 \sum_{i_1, i_2, i_3, i_4=1}^m [\langle\langle z_{i_1}^2 z_{i_2}^2 z_{i_3}^2 z_{i_4}^2 \rangle\rangle_G - \langle\langle z_{i_1}^2 z_{i_2}^2 \rangle\rangle_G \langle\langle z_{i_3}^2 z_{i_4}^2 \rangle\rangle_G] + O\left(\frac{1}{n^3}\right) \\ &= \frac{m}{2} \left(g_m - \frac{1}{G} \right)^2 G^2 - \frac{m(m+2)}{2} \left(g_m - \frac{1}{G} \right) v_m G^3 + \frac{m(m+2)(m+3)}{8} v_m^2 G^4 + O\left(\frac{1}{n^3}\right). \end{aligned} \quad (\text{A.49})$$

从第二行推到最后一行时，下面的高斯期望公式会很有用：

$$\sum_{i_1, \dots, i_k=1}^m \langle\langle z_{i_1}^2 \cdots z_{i_k}^2 \rangle\rangle_G = m(m+2) \cdots [m+2(k-1)] G^k, \quad (\text{A.50})$$

它类似于式 (3.46)，并将在下一小小节中反复使用，直至 $k=6$ 。为完成计算，把二次耦合 (A.47) 和四次耦合 (A.48) 代入式 (A.49)，得到

$$\langle\langle S_I^2 \rangle\rangle_G - \langle\langle S_I \rangle\rangle_G^2 = \frac{m(m+2)}{8} \left(\frac{V}{nG^2} \right)^2 + O\left(\frac{1}{n^3}\right), \quad (\text{A.51})$$

这就是变分作用量的方差. 因此, 熵 (A.45) 为

$$\mathcal{S}[p(z_1, \dots, z_m|x)] = \frac{m}{2} \log(2\pi eG) - \frac{(m^2 + 2m)}{16} \left(\frac{V}{nG^2} \right)^2 + O\left(\frac{1}{n^3}\right), \quad (\text{A.52})$$

它展现了有限宽下的非平凡修正.

下面对这一公式作几点评述. 第一, 正如前面指出的, 该修正确实为负: 高斯分布使一组协方差固定的随机变量的熵最大化; 而第一项变分约束 (A.35) 固定了预激活量的二点相关子, 因此近高斯分布 (A.30) 的熵必然小于方差相同的高斯分布的熵. 第二, 与此前所有结果不同, 这里的领先修正关于层宽倒数是二阶的, 即 $\sim V^2/n^2$, 而不是 $\sim V/n$. 事实上, 一般近高斯作用量中的四次耦合 v_m 可以取任一符号——分别对应厚尾或薄尾分布——所以, 为保证熵减小, 熵的领先修正必须正比于四次耦合平方的负值, 即 $v_m^2 \propto V^2/n^2$.³⁰³ 最后可见, 这项修正打破了无限宽极限 (A.26) 中神经元熵的完美可加性. 特别地, 熵的减小虽然在微扰意义下很小, 按 $1/n^2$ 标度, 但它还二次依赖于 m . 神经元数目上的这种非线性, 标志着有限宽下存在非平凡相互作用.

相应地, 可以计算两组互不重叠的神经元 $\mathcal{M}_1 = \{1, \dots, m_1\}$ 与 $\mathcal{M}_2 = \{m_1 + 1, \dots, m_1 + m_2\}$ 之间的互信息, 以刻画这种统计依赖:

$$\begin{aligned} \mathcal{I}[p(\mathcal{M}_1, \mathcal{M}_2|x)] &\equiv \mathcal{S}[p(\mathcal{M}_1|x)] + \mathcal{S}[p(\mathcal{M}_2|x)] - \mathcal{S}[p(\mathcal{M}_1, \mathcal{M}_2|x)] \\ &= \frac{m_1 m_2}{8} \left[\frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^2} \right]^2 + O\left(\frac{1}{n^3}\right), \end{aligned} \quad (\text{A.53})$$

这里以三种不同方式使用了熵公式 (A.52), 并恢复层指标, 以便更好地解释该公式. 这一非零互信息意味着, 仅在有限宽下, 对于给定层 ℓ , 观测一组神经元 $\mathcal{M}_1$ 的活动会传达关于另一组神经元 $\mathcal{M}_2$ 活动的信息. 这可以看作我们在 §6.4.1 中针对条件方差 (6.78) 看到的 Hebb 学习原理的信息论改写与推广: 在那里, 我们更简单地看到, 以第二个神经元的反常观测 $z_1^{(\ell)} = \tilde{z}_1^{(\ell)}$ 为条件时, 一个神经元 $z_2^{(\ell)}$ 的方差本身也会反常; 而在这里, 我们可以直接刻画一组神经元能够获知另一组不重叠神经元的多少信息.³⁰⁴

最后, 回顾归一化顶点的标度律 (5.128), 可见互信息 (A.53) 随隐藏层深度 ℓ 的平方标度:

$$\mathcal{I}[p(\mathcal{M}_1, \mathcal{M}_2|x)] \propto \ell^2/n^2. \quad (\text{A.54})$$

就 RG 流而言, 这意味着互信息是相关的, 表明不断增长的互信息有助于表征的粗粒化: 随着细粒度特征被边缘化, 较深隐藏层中不同神经元组之间的相关集合会不断增长. 换言之, 通过增大熵中的非线性次可加项, 它减少了这些更深层中独立可用的自由度数目.³⁰⁵

³⁰³同一论证排除了来自六次耦合、形如 $O(u_m) = O(U/n^2)$ 的贡献, 参见式 (A.55); 也类似地排除了来自其他高阶耦合的任何线性贡献.

³⁰⁴更一般地, 为理解互信息的数据依赖性, 计算多个输入的互信息会很有意义. 在那种情形下, 我们预期它由多输入四点顶点介导, 并依赖于数据集 $\mathcal{D}$ 中四个样本的不同分组细节.

³⁰⁵尝试用 [82] 的最优脑损伤或 [83] 的彩票假设来解释这一点, 会很有意义.

NLO 修正：最优深宽比与三元信息

有限宽互信息的领先阶结果 (A.54) 朴素地随深度无界增长，似乎网络总是越深越好。当然，如果深度过大，微扰级数中的高阶项就会变得重要，这一朴素答案也随之失效。为理解更大深度下的互信息，需要计算次领先阶 (NLO) 修正。

为把计算推进到下一阶，需要确保两个变分约束 (A.35) 和 (A.36) 在次领先阶 $O(1/n^2)$ 仍成立。原则上，这意味着还要在变分作用量 S_I 中加入一个 $O(1/n^2)$ 的六次项：

$$S_I(z_1, \dots, z_m) = \frac{1}{2} \left(g_m - \frac{1}{G} \right) \sum_{i=1}^m z_i^2 - \frac{1}{8} v_m \sum_{i,j=1}^m z_i^2 z_j^2 + \frac{1}{24} u_m \sum_{i,j,k=1}^m z_i^2 z_j^2 z_k^2 + O\left(\frac{1}{n^3}\right). \quad (\text{A.55})$$

这样的六次项最初在式 (ε.18) 中引入；这里将其特化到第 ℓ 层的 m 个预激活量，其中 u_m 是跑动六次耦合。

下面说明如何显式满足这些变分约束。首先，正如前面针对式 (A.45) 中的熵所做的那样，对一般可观测量，可以用较简单的高斯期望表示其完整期望：

$$\begin{aligned} \mathbb{E}[\mathcal{O}] &\equiv \frac{1}{Z} \int \left[\prod_{i=1}^m dz_i \right] e^{-S} \mathcal{O} = \left(\frac{Z}{Z_G} \right)^{-1} \langle\langle e^{-S_I} \mathcal{O} \rangle\rangle_G \\ &= \langle\langle \mathcal{O} \rangle\rangle_G - \left[\langle\langle \mathcal{O} S_I \rangle\rangle_G - \langle\langle \mathcal{O} \rangle\rangle_G \langle\langle S_I \rangle\rangle_G \right] \\ &\quad + \frac{1}{2} \left[\langle\langle \mathcal{O} S_I^2 \rangle\rangle_G - 2 \langle\langle \mathcal{O} S_I \rangle\rangle_G \langle\langle S_I \rangle\rangle_G - \langle\langle \mathcal{O} \rangle\rangle_G \langle\langle S_I^2 \rangle\rangle_G + 2 \langle\langle \mathcal{O} \rangle\rangle_G \langle\langle S_I \rangle\rangle_G^2 \right] + O\left(\frac{1}{n^3}\right), \end{aligned} \quad (\text{A.56})$$

最后一个等号中，我们按 S_I 展开了 $\langle\langle e^{-S_I} \mathcal{O} \rangle\rangle_G$ ，并使用了式 (A.43) 中已经算出的配分函数之比。从物理上说，第一组方括号表明，在相互作用理论中，可观测量的领先变分修正由该可观测量与作用量变分部分的相关性给出。

为满足度量的第一个约束 (A.35)，可以在一般表达式 (A.56) 中取可观测量

$$\mathcal{O} \equiv \frac{1}{m} \sum_{i=1}^m z_i^2, \quad (\text{A.57})$$

由约束 (A.35) 很容易看出 $\mathbb{E}[\mathcal{O}] = G$ 。再用六次变分作用量 (A.55) 计算同一期望，得到

$$\begin{aligned} G &= \frac{1}{m} \sum_{i=1}^m \mathbb{E}[z_i^2] \\ &= G - \left(g_m - \frac{1}{G} \right) G^2 + \frac{(m+2)}{2} v_m G^3 + \left(g_m - \frac{1}{G} \right)^2 G^3 - \frac{(m+2)(m+4)}{4} u_m G^4 \\ &\quad - \frac{3(m+2)}{2} \left(g_m - \frac{1}{G} \right) v_m G^4 + \frac{(m+2)(m+3)}{2} v_m^2 G^5 + O\left(\frac{1}{n^3}\right). \end{aligned} \quad (\text{A.58})$$

计算时，公式 (A.50) 会再次派上用场。表达式 (A.58) 展示了相互作用理论如何修正二点相关子。逐阶重排并解出 g_m ，便得到式 (A.47) 的 NLO 版本，它以度量和和其他高阶

耦合确定变分二次耦合：

$$g_m = \frac{1}{G} + \frac{(m+2)}{2}v_m G - \frac{(m+2)(m+4)}{4}u_m G^2 + \frac{(m+2)}{2}v_m^2 G^3 + O\left(\frac{1}{n^3}\right). \quad (\text{A.59})$$

其次，为满足四点顶点的第二个约束 (A.36)，在一般表达式 (A.56) 中取

$$\mathcal{O} \equiv \frac{1}{m(m+2)} \sum_{i,j=1}^m z_i^2 z_j^2, \quad (\text{A.60})$$

结合约束 (A.35) 与 (A.36) 可得 $\mathbb{E}[\mathcal{O}] = G^2 + V/n$. 再依据六次变分作用量 (A.55) 计算 $\mathcal{O}$ ，得到

$$G^2 + \frac{V}{n} = \frac{1}{m(m+2)} \sum_{i,j=1}^m \mathbb{E}[z_i^2 z_j^2] \quad (\text{A.61})$$

$$\begin{aligned} &= G^2 - 2\left(g_m - \frac{1}{G}\right)G^3 + 3\left(g_m - \frac{1}{G}\right)^2 G^4 + (m+3)v_m G^4 - \frac{(m+4)^2}{2}u_m G^5 \\ &\quad - 4(m+3)\left(g_m - \frac{1}{G}\right)v_m G^5 + \frac{(5m^2+34m+60)}{4}v_m^2 G^6 + O\left(\frac{1}{n^3}\right) \\ &= G^2 + v_m G^4 - (m+4)u_m G^5 + \frac{(m+8)}{2}v_m^2 G^6 + O\left(\frac{1}{n^3}\right), \end{aligned} \quad (\text{A.62})$$

从第一行到第二行再次大量使用了公式 (A.50)，而到最后一行则代入了二次耦合 (A.59). 逐阶重排并解出 v_m ，得到式 (A.48) 的 NLO 版本，它以两个约束和六次耦合确定变分四次耦合：

$$v_m = \frac{V}{nG^4} - \frac{(m+8)}{2}\left(\frac{V}{nG^3}\right)^2 + (m+4)u_m G + O\left(\frac{1}{n^3}\right). \quad (\text{A.63})$$

至此，计算熵 (A.45) 的 NLO 修正所需的材料终于齐备.³⁰⁶ 首先，反复使用公式 (A.50)，重新计算变分作用量的方差至 NLO：

$$\begin{aligned} &\langle\langle S_I^2 \rangle\rangle_G - \langle\langle S_I \rangle\rangle_G^2 \quad (\text{A.64}) \\ &= \frac{m}{2}\left(g_m - \frac{1}{G}\right)^2 G^2 - \frac{m(m+2)}{2}\left(g_m - \frac{1}{G}\right)v_m G^3 + \frac{m(m+2)(m+3)}{8}v_m^2 G^4 \\ &\quad + \frac{m(m+2)(m+4)}{4}\left(g_m - \frac{1}{G}\right)u_m G^4 - \frac{m(m+2)(m+4)^2}{8}v_m u_m G^5 + O\left(\frac{1}{n^4}\right) \\ &= \frac{m(m+2)}{8}\left[(v_m G^2)^2 - 2(m+4)(v_m G^2)(u_m G^3)\right] + O\left(\frac{1}{n^4}\right) \\ &= \frac{m(m+2)}{8}\left[\left(\frac{V}{nG^2}\right)^2 - (m+8)\left(\frac{V}{nG^2}\right)^3\right] + O\left(\frac{1}{n^4}\right). \end{aligned}$$

³⁰⁶原则上，在这一阶还需要继续求出 u_m 关于额外六点顶点约束的表达式；但很快就会看到， u_m 不会进入任何互信息表达式. 正因如此，无须另外计算更多 MLP 递推，就能分析这些次领先阶修正.

从第二行到倒数第二行使用了二次耦合的 NLO 表达式 (A.59)，再用四次耦合的 NLO 表达式 (A.63) 得到最后一行。其次，类似地计算熵表达式 (A.45) 中的次领头项：

$$\begin{aligned}
 & \langle S_I^3 \rangle_G - 3 \langle S_I^2 \rangle_G \langle S_I \rangle_G + 2 \langle S_I \rangle_G^3 \\
 &= m \left(g_m - \frac{1}{G} \right)^3 G^3 - \frac{9m(m+2)}{4} \left(g_m - \frac{1}{G} \right)^2 v_m G^4 \\
 & \quad + \frac{3m(m+2)(m+3)}{2} \left(g_m - \frac{1}{G} \right) v_m^2 G^5 - \frac{m(m+2)(5m^2+34m+60)}{16} v_m^3 G^6 + O\left(\frac{1}{n^4}\right) \\
 &= -\frac{m(m+2)(m+8)}{8} (v_m G^2)^3 + O\left(\frac{1}{n^4}\right) \\
 &= -\frac{m(m+2)(m+8)}{8} \left(\frac{V}{nG^2} \right)^3 + O\left(\frac{1}{n^4}\right).
 \end{aligned} \tag{A.65}$$

把式 (A.64) 和 (A.65) 代回熵的变分表达式 (A.45)，最终得到

$$\begin{aligned}
 & \mathcal{S}[p(z_1, \dots, z_m|x)] \\
 &= \frac{m}{2} \log(2\pi eG) - \frac{(m^2+2m)}{16} \left(\frac{V}{nG^2} \right)^2 + \frac{(m^3+10m^2+16m)}{48} \left(\frac{V}{nG^2} \right)^3 + O\left(\frac{1}{n^4}\right).
 \end{aligned} \tag{A.66}$$

进而可以计算两组神经元 $\mathcal{M}_1 = \{1, \dots, m_1\}$ 和 $\mathcal{M}_2 = \{m_1+1, \dots, m_1+m_2\}$ 之间互信息的 NLO 修正：

$$\begin{aligned}
 & \mathcal{I}[p(\mathcal{M}_1, \mathcal{M}_2|x)] \\
 & \equiv \mathcal{S}[p(\mathcal{M}_1|x)] + \mathcal{S}[p(\mathcal{M}_2|x)] - \mathcal{S}[p(\mathcal{M}_1, \mathcal{M}_2|x)] \\
 &= \frac{m_1 m_2}{8} \left[\frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^2} \right]^2 - \frac{m_1 m_2 (20+3m_1+3m_2)}{48} \left[\frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^2} \right]^3 + O\left(\frac{1}{n^4}\right),
 \end{aligned} \tag{A.67}$$

这里再次恢复了度量、四点顶点和层宽的层指标。还要注意，正如所承诺的，六次耦合 u_m 最终消去了。³⁰⁷

令人振奋的是，这两项符号相反。为解释这一点，把在最终层 $\ell = L$ 处求值的归一化四点顶点标度解 (5.128) 代入：

$$\frac{V^{(L)}}{n_{L-1} (G^{(L)})^2} \equiv \nu r. \tag{A.68}$$

这里 $r \equiv L/n$ 是网络整体的深宽比，而 ν 是依赖激活函数的常数。对 $K^* = 0$ 普适类，由式 (5.131) 有

$$\nu = \frac{2}{3}, \tag{A.69}$$

它不依赖激活函数自身的细节；对尺度不变激活函数，由式 (5.130) 有

$$\nu = \left(\frac{3A_4}{A_2^2} - 1 \right), \tag{A.70}$$

其中 $A_2 \equiv (a_+^2 + a_-^2)/2$ 且 $A_4 \equiv (a_+^4 + a_-^4)/2$ 。³⁰⁸ 把标度解 (A.68) 代入互信息的 NLO 表

³⁰⁷ 这是近高斯分布最大熵原理的又一体现。具体来说，一个零均值分布若满足固定二点相关子和连通四点相关子的约束，而连通六点相关子仍不固定，则其熵到 $1/n^3$ 阶由表达式 (A.66) 给出。因此，即使再加入第三个约束，把连通六点相关子固定为 $U = O(1/n^2)$ ，式 (A.66) 中也不能出现 $O(v_m u_m) = O(UV/n^3)$ 形式的项，因为它们可能随 UV 的符号而增大熵。

³⁰⁸ 对 linear 激活有 $\nu = 2$ ，对 ReLU 有 $\nu = 5$ 。

达式 (A.67), 得到

$$\mathcal{I}[p(\mathcal{M}_1, \mathcal{M}_2|x)] = \frac{m_1 m_2}{8} \nu^2 r^2 - \frac{m_1 m_2 (20 + 3m_1 + 3m_2)}{48} \nu^3 r^3 + O(r^4). \quad (\text{A.71})$$

下面解释为何这令人振奋. 在一个极端, 即无限宽极限 $r \rightarrow 0$, 互信息如式 (A.27) 所示为零. 因而对小深宽比 $r \ll 1$, 第一个领先阶项占主导, 互信息随深度增加. 深度继续增加时, 第二项开始占主导, 使互信息减小. 但由熵的次可加性及式 (A.15) 可知, 互信息总以零为下界, 因此在足够大的深宽比 r 下, 这种减小会被额外的高阶修正抵消. 综合来看, 互信息应当会在某个非零但又不过大的 r 处达到局部最大值. 确实, 最大化式 (A.71), 得到网络的**最优深宽比**:

$$r^* = \left(\frac{4}{20 + 3m_1 + 3m_2} \right) \frac{1}{\nu}, \quad (\text{A.72})$$

其中 ν 包含激活函数的全部细节.³⁰⁹

虽然并非一目了然, 但最大化式 (A.68) 这样的互信息, 与著名的**无监督学习目标**密切相关.³¹⁰ 与监督学习以对任意输入样本 x 预测真实输出 $y \equiv f(x)$ 为目标不同, 无监督学习以通过观察数据中的模式来学习一组输入样本的表征为目标. 对人工生成的数据集而言, 这免去了标注所有样本的繁琐工作. 考虑到表征学习 (§11) 的益处, 也不难理解: 用无监督学习算法 (预) 训练的模型, 往往可以在后续监督学习任务上高效微调.

在当前语境中, 我们并不实际执行任何学习, 而是先验地理解怎样选择架构和激活函数, 才能使深层中神经元之间的互信息更大.³¹¹ 特别地, 比较不同激活函数下式 (A.69) 与 (A.70) 中的 ν , 原则上可见: 要在某一层获得相同互信息, 采用 $\tanh$ 激活函数的网络应比采用 ReLU 激活函数的网络更深.

循此目标, 还应在所有可能的划分 (m_1, m_2) 上继续最大化式 (A.71). 这选出了一个非常自然的划分: 它跨越整层, 并把整层等分, 即 $m_1 = m_2 = n_L/2$. 进一步最大化得到最优深宽比

$$r^* = \left(\frac{4}{20 + 3n_L} \right) \frac{1}{\nu}, \quad (\text{A.73})$$

以及相应的最大互信息

$$\mathcal{I}[p(\mathcal{M}_1, \mathcal{M}_2|x)] = \frac{1}{6} \left(\frac{n_L}{20 + 3n_L} \right)^2, \quad (\text{A.74})$$

特别地, 这对应于脚注 310 中所述 InfoMax 目标的一个下界.³¹²

³⁰⁹不必担心求解式 (A.72) 时忽略的高阶贡献 $O(r^4)$: 对特定激活函数, 即给定 ν , 只要对该 ν 和特定神经元分组 (m_1, m_2) 而言乘积 νr^* 在微扰意义下很小, 对最优值 (A.72) 的估计便可事后自治. 顺便一提, 这一论证类似于非阿贝尔规范理论中为重整化群流的两圈 Banks-Zaks 不动点所作的论证 [84].

³¹⁰具体而言, InfoMax 原理 [85] 建议最大化输入 x 与表征 $z(x)$ 之间的互信息. 一个相关概念, 是最大化同一输入 x 的不同表征 $z_1(x)$ 与 $z_2(x)$ 之间的互信息 [86]. 可以证明, 后一概念给出了 InfoMax 目标的下界, 从而为这里的分析提供动机.

³¹¹类似地, 可以把临界性分析看作一种无监督学习或预训练准则: 我们先验地理解怎样选择初始化超参数, 才能得到训练后泛化最稳健的系综, 参见 §10.3.

³¹²虽然式 (A.74) 的数值看起来很小, 但要记住, 我们的分析完全基于任何学习发生之前的先验分布.

关于式 (A.73)，最后再评论一点：可以把这一最优深宽比看成一个尺度，它将有效理论适用的有效深区间与理论强耦合、网络不再可训练的过深区间分隔开。下一附录讨论残差网络时，我们会进一步发展这一解释。

作为最后一个计算，考察三个互不重叠的子系统 $\mathcal{M}_1$ 、 $\mathcal{M}_2$ 和 $\mathcal{M}_3$ 的三元信息 (A.24)，它们分别包含 (m_1, m_2, m_3) 个神经元。对不同的大小组合代入式 (A.66)，得到

$$\mathcal{I}_3[p(\mathcal{M}_1, \mathcal{M}_2, \mathcal{M}_3|x)] = \frac{m_1 m_2 m_3}{8} \left[\frac{V^{(\ell)}}{n_{\ell-1} (G^{(\ell)})^2} \right]^3 + O\left(\frac{1}{n^4}\right), \quad (\text{A.75})$$

根据式 (5.128)，它随深度作三次标度，即 $\mathcal{I}_3[p(\mathcal{M}_1, \mathcal{M}_2, \mathcal{M}_3|x)] \propto \ell^3/n_{\ell-1}^3$ ；因此非零结果首次出现于 $O(1/n^3)$ 。³¹³ 重要的是，三元信息总为正，这意味着在 RG 流下，任意三组神经元都会形成冗余的表征：已知一组神经元 $\mathcal{M}_1$ 的活动后，再观测第三组 $\mathcal{M}_3$ ，所能获得的关于第二组 $\mathcal{M}_2$ 的信息，会少于尚不知道 $\mathcal{M}_1$ 时所能获得的信息。进一步理解这一性质如何关联于表征群流向更深层的粗粒化机制，将很有意义。³¹⁴

³¹³回头来看这一点很显然：正如要得到非零互信息 (A.53)，熵至少需要二次依赖于各组大小；要得到非零三元信息，熵至少需要三次依赖于 m_i 。

³¹⁴尝试用 [82] 的最优脑损伤或 [83] 的彩票假设来解释这一点，也会很有意义。

第 B 章

残差学习

不是，博士，不是我，是另一个我！就是台上演奏 *Johnny B. Goode* 的那个！

马蒂·麦克弗莱 [87].

在这最后一个附录中，我们将分析带有残差连接的神经网络，通常称为**残差网络**。这类网络最初是为了训练越来越深的网络而引入的：传统深层网络会遭遇梯度爆炸与消失问题；然而，即使使用各种经验技巧来保证前向与反向信号传播，实验上仍发现，过深网络的训练误差和测试误差都高于较浅网络。

从微观视角看，对参数更多的深层模型而言，泛化误差增大并不难理解，但训练误差增大却并非如此：增加的参数朴素地说应当能让模型更好地拟合训练数据。至少，人们或许会希望额外各层原则上可以逼近恒等映射，从而不会更差。但上述经验证据表明，优化算法很难把深层网络的隐藏层调成这种近恒等映射。这称为**退化**，原则上是开发更大规模深度学习模型的主要限制因素。

从有效理论的宏观视角出发，可以为退化问题给出一个对偶的解释。在解释之前，先回顾：为解决梯度爆炸与消失问题，我们并未采用启发式方法，而是在 §9.4 中借助临界性解析解决了它的指数表现，再借助学习率等效原理解决了它的多项式表现。在 §10.3 中还进一步确认，相应地调节初始化超参数 $C_b^{(\ell)}$ 、 $C_W^{(\ell)}$ 和训练超参数 $\lambda_b^{(\ell)}$ 、 $\lambda_W^{(\ell)}$ ，会使 MLP 获得最稳健的泛化性能。

现在，即使这些超参数都已适当调节，我们仍预期过深网络会严重受到不同实例之间涨落的影响，导致任一特定网络偏离临界性。这一问题最初在 §3.4 中针对极深（线性）网络讨论，随后在 §5.4 中作了一般讨论，最后又见尾声 ϵ 的脚注 282。因而，结合 §A.3 中对 MLP 深宽比 $r \equiv L/n$ 的讨论，或许可以把训练损失的退化理解为：网络离开最优区间并走向混沌区间。

现在请把微观解释重新放回思考的前景，我们便能说明 He 等人 [88] 针对退化提出的巧妙解法。与其设法寻找更好的学习算法，不如修改深层网络架构，使隐藏层只需学习一个残差函数。不再采用一般的非线性第 $(\ell + 1)$ 层

$$z^{(\ell+1)} = \mathbf{L}(z^{(\ell)}; \theta^{(\ell+1)}), \quad (\text{B.1})$$

而把该层设计成

$$z^{(\ell+1)} = \mathbf{R}(z^{(\ell)}; \theta^{(\ell+1)}) + z^{(\ell)}, \quad (\text{B.2})$$

使**残差块** $\mathbf{R}(z^{(\ell)}; \theta^{(\ell+1)})$ 成为希望该层 (B.1) 实现的函数之残差。这种一般残差层的基本结构画在图 B.1 左侧，后文还会进一步说明。




图 B.1: 左：一个非常一般的残差网络中，相邻两层的两个残差块. 这一细致结构展示了每一层如何：(i) 把加权后的块与加权后的预激活量相加，产生下一层预激活量；(ii) 复制预激活量，使其跳至下一层；以及 (iii) 生成下一层的块. 右：残差 MLP 中相邻两层的两个神经元. 这一细致结构展示了每一层如何：(i) 把偏置、加权后的激活值和加权后的预激活量相加，产生下一层预激活量；(ii) 复制预激活量，使其跳至下一层；(iii) 由预激活量生成激活值；以及 (iv) 将激活值乘以下一层权重.

从微观视角看，这些残差连接使学习近恒等映射容易得多。确实，把残差块 $R(z^{(\ell)}; \theta^{(\ell+1)})$ 调到接近零，远比促使一般非线性函数 $L(z^{(\ell)}; \theta^{(\ell+1)})$ 逼近恒等映射容易。特别地，神经网络的标准构件往往在参数设为零时也为零——MLP 层块可参见式 (2.5)——而典型初始化分布的均值为零——参见式 (2.21) 和 (2.22)。因此，残差网络很容易找到满足 $R(z^{(\ell)}; \theta^*) \approx 0$ 的解，使增加隐藏层不一定会降低网络性能。

更一般地，我们希望预激活量实际扮演两种角色：一是依据表征群流 (§4.6) 对输入信号作粗粒化，二是传播一份未退化的输入信号副本。这很可能相当有用，因为它使我们能够训练参数更多的更深模型；实验上也确已证明，这种更深的残差网络能显著改善测试集性能。

本附录的目标之一，是从对偶的宏观角度解释残差连接为何让我们能够训练过深网络。上面对退化来源的宏观解释，加上极深残差网络在实验上的成功，说明加入残差连接会把最优深宽比 r^* 从 MLP 的值 (A.72) 推向更大的数值。这会扩展有效深网络的范围，从而解释残差连接为何允许训练更深的网络。为检验这一假设，需要对残差网络开展有效理论分析。

尽管前奏很长，本附录却相对简短，只涉及一些简单计算。这些练习有两个目的。第一，现代深度学习架构中**残差连接**无处不在；它有时也称为跳跃连接或捷径。因而，说明加入残差连接后临界初始化超参数如何偏移，具有实际用处。第二，这会展示如何轻松地把有效理论形式体系应用到普通 MLP 之外的神经网络架构。

为此——也为了走到本书终点——我们会先在 §B.1 中简要介绍或许最简单的残差网络，即带残差连接的多层感知机。在 §B.2 中，我们将研究该模型的无限宽极限，并作临界性分析，以理解残差超参数如何与临界初始化超参数相互作用。

随后，在 §B.3 中研究有限宽残差 MLP。利用上一附录中的辅助无监督学习目标，我们会看到加入残差连接如何把网络的最优深宽比 r^* 推到较大数值。还会看到，对深宽比低于某个阈值的网络，按照这一判据，残差连接总是有害的。总体而言，这为残差连接如何解决上述退化问题提供了一个新的有效理论宏观视角，还让我们理解信号通过残差块——这里即非线性 MLP 层块——传播与通过恒等块——即跳过信号、传至更深层——传播之间的权衡。

最后，在 §B.4 中，我们会给出一个理论与经验相结合的方案，把前两节的分析应用于具有任意复杂残差块 $R(z^{(\ell)}; \theta^{(\ell+1)})$ 的一般残差网络。我们希望，这一方案可以广泛应用于众多实现了残差连接的深度学习架构。³¹⁵ 此后，你就从本书学完了全部残差学习内容。

³¹⁵残差网络最初由 He 等人 [88] 描述。通常，当一个残差网络被称为 *ResNet* 时，其基础块由卷积层组成，参见式 (2.8)；此外还会加入一种非常流行的、用于缓解梯度爆炸与消失问题的启发式方法 [89]。ResNet 最初用于计算机视觉任务，如今则已应用到其他领域；更广泛地说，残差连接是各种现代深度学习架构的组成部分，其中一个重要例子就是基于 transformer 的语言模型，它们正在革新自然语言处理 [14]。

B.1 残差多层感知机

带残差连接的多层感知机可以由如下前向方程定义：

$$z_{i;\delta}^{(\ell+1)} = \xi^{(\ell+1)} \left[b_i^{(\ell+1)} + \sum_{j=1}^{n_\ell} W_{ij}^{(\ell+1)} \sigma_{j;\delta}^{(\ell)} \right] + \gamma^{(\ell+1)} z_{i;\delta}^{(\ell)}. \quad (\text{B.3})$$

与示意描述 (B.2) 相比，这里只选取标准 MLP 层作为残差块 $\mathbf{R}(z^{(\ell)}; \theta^{(\ell+1)})$ ，并允许引入标量**残差超参数** $\xi^{(\ell)}$ 和 $\gamma^{(\ell)}$ ，用来控制残差块项与恒等项的相对大小。这里需要取

$$n_\ell = n_{\ell+1} \equiv n \quad (\text{B.4})$$

这样才能把加权且加上偏置的激活值，加回到激活之前的预激活量上；因而，这种残差连接只包含在网络的隐藏层中。³¹⁶ 图 B.1 右侧画出了残差 MLP 相邻两层中的两个神经元；如果需要回顾 MLP 的整体全局结构，请参见图 2.1.

虽然保留两个残差超参数在对称性上很美观，但其中一个冗余的：可以证明，调节 $\xi^{(\ell)}$ 对残差 MLP 系综的影响，与重新缩放初始化超参数 $C_b^{(\ell)}$ 、 $C_W^{(\ell)}$ 和训练超参数 $\lambda_b^{(\ell)}$ 、 $\lambda_W^{(\ell)}$ 的影响相同。因此，以下将不失一般性地令

$$\xi^{(\ell)} = 1, \quad (\text{B.6})$$

于是只剩下一个（可能逐层变化的）残差超参数 $\gamma^{(\ell)}$ 。特别要注意，在 $\gamma^{(\ell)} \rightarrow 0$ 的极限下，我们恢复了没有任何残差连接的普通 MLP。这个超参数的一种惯常选择是 $\gamma^{(\ell)} = 1$ ，参见式 (B.2)；但下面将说明，这一选择并非最优，因为它会破坏临界性。³¹⁷

B.2 残差无限宽：临界性分析

为了理解如何设置残差超参数 $\gamma^{(\ell)}$ 并保持残差 MLP 的临界性，下面推导二点相关子的递推关系：

$$\mathbb{E} \left[z_{i_1;\delta_1}^{(\ell)} z_{i_2;\delta_2}^{(\ell)} \right] = \delta_{i_1 i_2} G_{\delta_1 \delta_2}^{(\ell)}. \quad (\text{B.7})$$

利用前向方程 (B.3)，可得

$$G_{\delta_1 \delta_2}^{(\ell+1)} = C_b + C_W \frac{1}{n} \sum_{j=1}^n \mathbb{E} \left[\sigma_{j;\delta_1}^{(\ell)} \sigma_{j;\delta_2}^{(\ell)} \right] + \gamma^2 G_{\delta_1 \delta_2}^{(\ell)}. \quad (\text{B.8})$$

³¹⁶更一般地，如果希望 $n_{\ell+1} \neq n_\ell$ ，则可以改用如下迭代方程：

$$z_{i;\delta}^{(\ell+1)} = \sum_{j=1}^{n_{\ell+1}} \xi_{ij}^{(\ell+1)} \left[b_j^{(\ell+1)} + \sum_{k=1}^{n_\ell} W_{jk}^{(\ell+1)} \sigma_{k;\delta}^{(\ell)} \right] + \sum_{j=1}^{n_\ell} \gamma_{ij}^{(\ell+1)} z_{j;\delta}^{(\ell)}, \quad (\text{B.5})$$

此时残差超参数为矩阵： $\xi_{ij}^{(\ell+1)}$ 是一个 $n_{\ell+1} \times n_{\ell+1}$ 矩阵， $\gamma_{ij}^{(\ell+1)}$ 是一个 $n_{\ell+1} \times n_\ell$ 矩阵；一般而言，这两个矩阵都可以逐层变化。

³¹⁷具体而言，如果没有任何额外的启发式方法，例如 [89]，来以其他方式缓解梯度爆炸与消失问题，这一选择就会产生问题。因而，下面的分析也解释了为什么不采用这类启发式方法的深层 $\gamma^{(\ell)} = 1$ 残差网络总会表现不佳。

与此前多到无法逐一列举引用的所有临界性讨论相仿，在本节中始终令偏置方差 $C_b^{(\ell)}$ 、重标度权重方差 $C_W^{(\ell)}$ 和残差超参数 $\gamma^{(\ell)}$ 在各层之间一致：

$$C_b^{(\ell)} = C_b, \quad C_W^{(\ell)} = C_W, \quad \gamma^{(\ell)} = \gamma. \quad (\text{B.9})$$

与普通 MLP 的度量递推关系 (4.72)

$$G_{\delta_1 \delta_2}^{(\ell+1)} = C_b + C_W \frac{1}{n} \sum_{j=1}^n \mathbb{E} \left[\sigma_{j;\delta_1}^{(\ell)} \sigma_{j;\delta_2}^{(\ell)} \right], \quad (\text{B.10})$$

相比，前向方程中的（重标度）恒等项使残差 MLP 第 $(\ell+1)$ 层的度量发生偏移，从而在式 (B.8) 的最后一项中，额外贡献了（重标度后的）第 ℓ 层度量。

特别地，残差 MLP 的无限宽极限给出如下核递推关系：

$$K_{\delta_1 \delta_2}^{(\ell+1)} = C_b + C_W \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(\ell)}} + \gamma^2 K_{\delta_1 \delta_2}^{(\ell)}. \quad (\text{B.11})$$

接下来，在 $\gamma^{[a]}$ 基底中按式 (5.15) 展开核，再使用式 (5.22)–(5.24) 的 δ 展开，就可以依照 §5.1 的双输入微扰分析导出分量递推关系

$$K_{00}^{(\ell+1)} = C_b + C_W g(K_{00}^{(\ell)}) + \gamma^2 K_{00}^{(\ell)}, \quad (\text{B.12})$$

$$\delta K_{[1]}^{(\ell+1)} = \chi_{\parallel} \left(K_{00}^{(\ell)} \right) \delta K_{[1]}^{(\ell)}, \quad (\text{B.13})$$

$$\delta \delta K_{[2]}^{(\ell+1)} = \chi_{\perp} \left(K_{00}^{(\ell)} \right) \delta \delta K_{[2]}^{(\ell)} + h \left(K_{00}^{(\ell)} \right) \left(\delta K_{[1]}^{(\ell)} \right)^2, \quad (\text{B.14})$$

它们是在普通表达式 (5.46)–(5.48) 基础上修改而来。³¹⁸ 这里，平行感受率

$$\chi_{\parallel}(K) \equiv \gamma^2 + \frac{C_W}{2K^2} \langle \sigma(z) \sigma(z) (z^2 - K) \rangle_K, \quad (\text{B.15})$$

和垂直感受率

$$\chi_{\perp}(K) \equiv \gamma^2 + C_W \langle \sigma'(z) \sigma'(z) \rangle_K, \quad (\text{B.16})$$

各自都在原先的值 (5.50) 和 (5.51) 上偏移了一个常数 γ^2 项，而辅助函数 $g(K)$ 和 $h(K)$ ，即式 (5.49) 和 (5.52)，则与之前相同：

$$g(K) \equiv \langle \sigma(z) \sigma(z) \rangle_K, \quad (\text{B.17})$$

$$h(K) \equiv \frac{1}{2} \frac{d}{dK} \chi_{\perp}(K). \quad (\text{B.18})$$

这项简单分析已经清楚表明，加入残差连接 ($\gamma \neq 0$) 会使临界初始化超参数发生偏移。固定临界性条件

$$\chi_{\parallel}(K^*) = 1, \quad \chi_{\perp}(K^*) = 1, \quad (\text{B.19})$$

³¹⁸注意，根据第一个递推关系 (B.12)，单输入量的一个微扰 $K_{00}^{(\ell)} = K_{00}^* + \Delta K_{00}^{(\ell)}$ 由偏移后的平行感受率 (B.15) 控制，参见式 (5.9)。

便可求得各个普适类的新临界初始化. 具体而言, 对尺度不变普适类, 临界初始化超参数 (5.67) 修改为

$$C_b = 0, \quad C_W = C_W(\gamma) \equiv \frac{1}{A_2} (1 - \gamma^2), \quad (\text{B.20})$$

其中 $A_2 \equiv (a_+^2 + a_-^2)/2$, 参见式 (5.59); 类似地, 对 $K^* = 0$ 普适类, 临界初始化超参数 (5.90) 修改为

$$C_b = 0, \quad C_W = C_W(\gamma) \equiv \frac{1}{\sigma_1^2} (1 - \gamma^2), \quad (\text{B.21})$$

其中 $\sigma_1 \equiv \sigma'(0)$.

我们在 §2.3 中讨论过, 零初始化 $b_i^{(\ell)} = W_{ij}^{(\ell)} = 0$ 无法打破隐藏层 n 个神经元之间的置换对称性. 结合这一推理, 现在可见, 对残差超参数的惯常选择 $\gamma = 1$, 任一普适类的临界性条件 (B.20) 和 (B.21) 都无法满足. 更广泛地说, 每个普适类都有一个临界重标度权重方差的单参数族: 对每个 $0 < \gamma^2 < 1$, 都有一个相应的临界值 $C_W = C_W(\gamma)$. 因而, 为了直接缓解梯度爆炸与消失问题, 对给定的 $0 < \gamma^2 < 1$ 和激活函数, 必须根据适当的 $C_W(\gamma)$ 来选择 C_W .

B.3 残差有限宽：最优深宽比

根据无限宽分析, 我们刚刚看到, 残差网络具有一个临界解的单参数族: $C_W(\gamma)$. 由核递推关系 (B.11) 可知, 这些解权衡了恒等分支与 MLP 层分支对下一层预激活量的贡献程度. 在严格的无限宽极限下, 临界性保证: 对范围 $0 < \gamma^2 < 1$ 内的任意选择 $C_W(\gamma)$, 核都得以保持, 而所有涨落都受到抑制; 因此原则上, 我们对这些临界调节中的任何一种都完全无所谓.

然而, 正如现在应该已经熟悉的讨论要点, 无限宽极限中的网络实际上具有趋于零的深宽比 $r \equiv L/n \rightarrow 0$. 这意味着, 无限宽分析无法真正触及退化问题: 为什么极深网络的训练误差高于其他方面等价的较浅网络. 为了比较深度不同的宽网络, 需要考虑具有不同深宽比 $r > 0$ 的有限宽网络.³¹⁹

本节的主要分析工具, 是计算残差 MLP 深层中互不重叠的表征之间的初始化互信息. 根据上一附录中的辅助无监督学习判据, 参见脚注 310 (位于 §A.3), 该互信息给出一种估计有限宽网络最优深宽比 r^* 的自然方法. 既然没有梯度爆炸与消失问题的残差网络解决了退化问题, 那么对残差 MLP, 一个自然的理论预测就是: 加入残差连接 ($\gamma > 0$), 再按照 $C_W(\gamma)$ 调至临界性, 两者会共同把其最优深宽比推向更大的数值.

为了利用公式 (A.73) 计算最优深宽比, 只需计算残差 MLP 的归一化输出层单输

³¹⁹具体而言, 在有限宽下, 穿过 MLP 层块的表征群流会产生两种相互竞争的有限宽效应: (i) 相关的、因而增长的 dNTK 和 ddNTK 在训练期间带来非平凡的表征学习; 以及 (ii) 相关的、增长的四点顶角、NTK 方差和 NTK-预激活量互相关, 使系综在不同实例之间产生涨落. 残差连接本应通过恒等分支复印未退化的输入来缓解第二种有害效应, 因此自然预期它们会对这种竞争产生有意义的物理影响. 换言之, 我们预期, 残差超参数 γ 和深宽比 r 不同的残差网络会给出很不相同的测试集泛化性能.

入四点顶角的系数 ν :

$$\frac{V^{(L)}}{n(G^{(L)})^2} \equiv \nu r. \quad (\text{B.22})$$

注意，我们已经在式 (B.12) 中推导了领头阶单输入度量，即核 $K^{(L)} \equiv G^{\{0\}(L)}$ 的递推关系. 为计算四点顶角，先回顾多输入四点顶角按如下方式定义四点连通相关子 (4.77):

$$\begin{aligned} & \mathbb{E} \left[z_{i_1;\delta_1}^{(\ell)} z_{i_2;\delta_2}^{(\ell)} z_{i_3;\delta_3}^{(\ell)} z_{i_4;\delta_4}^{(\ell)} \right] \Big|_{\text{connected}} \\ &= \frac{1}{n} \left[\delta_{i_1 i_2} \delta_{i_3 i_4} V_{(\delta_1 \delta_2)(\delta_3 \delta_4)}^{(\ell)} + \delta_{i_1 i_3} \delta_{i_2 i_4} V_{(\delta_1 \delta_3)(\delta_2 \delta_4)}^{(\ell)} + \delta_{i_1 i_4} \delta_{i_2 i_3} V_{(\delta_1 \delta_4)(\delta_2 \delta_3)}^{(\ell)} \right]. \end{aligned} \quad (\text{B.23})$$

利用前向方程 (B.3)，并沿用 §4.3 的分析，可以看出，与普通 MLP 的领头阶递推关系 (4.90) 相比，残差 MLP 的四点顶角递推关系偏移了两个分别正比于 γ^2 和 γ^4 的附加项:

$$\begin{aligned} & V_{(\delta_1 \delta_2)(\delta_3 \delta_4)}^{(\ell+1)} \\ &= C_W^2 [\langle \sigma_{\delta_1} \sigma_{\delta_2} \sigma_{\delta_3} \sigma_{\delta_4} \rangle_{K^{(\ell)}} - \langle \sigma_{\delta_1} \sigma_{\delta_2} \rangle_{K^{(\ell)}} \langle \sigma_{\delta_3} \sigma_{\delta_4} \rangle_{K^{(\ell)}}] \\ &+ \frac{C_W^2}{4} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} V_{(\ell)}^{(\delta_5 \delta_6)(\delta_7 \delta_8)} \langle \sigma_{\delta_1} \sigma_{\delta_2} (z_{\delta_5} z_{\delta_6} - K_{\delta_5 \delta_6}) \rangle_{K^{(\ell)}} \langle \sigma_{\delta_3} \sigma_{\delta_4} (z_{\delta_7} z_{\delta_8} - K_{\delta_7 \delta_8}) \rangle_{K^{(\ell)}} \\ &+ C_W \gamma^2 \left[\langle \sigma_{\delta_1} \sigma_{\delta_2} (z_{\delta_3} z_{\delta_4} - K_{\delta_3 \delta_4}) \rangle_{K^{(\ell)}} + \langle \sigma_{\delta_3} \sigma_{\delta_4} (z_{\delta_1} z_{\delta_2} - K_{\delta_1 \delta_2}) \rangle_{K^{(\ell)}} \right. \\ &\quad + \frac{1}{2} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} V_{(\ell)}^{(\delta_5 \delta_6)(\delta_7 \delta_8)} \langle \sigma_{\delta_1} \sigma_{\delta_2} (z_{\delta_5} z_{\delta_6} - K_{\delta_5 \delta_6}) \rangle_{K^{(\ell)}} K_{\delta_7 \delta_3}^{(\ell)} K_{\delta_8 \delta_4}^{(\ell)} \\ &\quad \left. + \frac{1}{2} \sum_{\delta_5, \dots, \delta_8 \in \mathcal{D}} V_{(\ell)}^{(\delta_5 \delta_6)(\delta_7 \delta_8)} \langle \sigma_{\delta_3} \sigma_{\delta_4} (z_{\delta_5} z_{\delta_6} - K_{\delta_5 \delta_6}) \rangle_{K^{(\ell)}} K_{\delta_7 \delta_1}^{(\ell)} K_{\delta_8 \delta_2}^{(\ell)} \right] \\ &+ \gamma^4 V_{(\delta_1 \delta_2)(\delta_3 \delta_4)}^{(\ell)}, \end{aligned} \quad (\text{B.24})$$

在解读这个表达式时，请记住，四点顶角的上标是与第 ℓ 层逆核作缩并的简写，参见式 (4.83). 此外，在推导正比于 γ^2 的中间各项时，层内公式 (4.64) 可能会有帮助.

现在专门考察单输入情形，得到

$$V^{(\ell+1)} = C_W^2 \left[\langle \sigma^4(z) \rangle_{K^{(\ell)}} - \langle \sigma^2(z) \rangle_{K^{(\ell)}}^2 \right] + \left(\chi_{\parallel}^{(\ell)} \right)^2 V^{(\ell)} + 4\gamma^2 \left(\chi_{\parallel}^{(\ell)} - \gamma^2 \right) \left(K^{(\ell)} \right)^2, \quad (\text{B.25})$$

为方便起见，这里像往常一样简记 $\chi_{\parallel}^{(\ell)} \equiv \chi_{\parallel}(K^{(\ell)})$. 这里的平行感受率是适用于残差 MLP 的偏移后感受率，定义见式 (B.15)，其中包含 γ^2 项；除此之外，我们还注意到，与普通 MLP 的单输入递推关系 (5.109) 相比，多出了依赖 γ 的最后一项. 在临界性处 $\chi_{\parallel}^{(\ell)} = 1$ ，这最后一项会对四点顶角的深层渐近行为产生非平凡影响. 现在取通常的初始条件 $V^{(1)} = 0$ (参见 §4.1 的标题)，在临界性处对两个普适类求解这一递推关系.

尺度不变普适类

对尺度不变普适类，利用式 (B.20) 把重标度权重方差调至临界性，使 $\chi_{\parallel}^{(\ell)} = 1$ 。此时单输入核被精确固定为 $K^{(\ell)} = K^*$ ，还需回顾式 (5.113)：

$$\left[\langle \sigma^4 \rangle_{K^*} - \langle \sigma^2 \rangle_{K^*}^2 \right] = (3A_4 - A_2^2) (K^*)^2, \quad (\text{B.27})$$

其中 $A_2 \equiv (a_+^2 + a_-^2)/2$ ， $A_4 \equiv (a_+^4 + a_-^4)/2$ 。把这些结果全部代入式 (B.26)，递推关系变为

$$V^{(\ell+1)} = V^{(\ell)} + (1 - \gamma^2) \left[(1 - \gamma^2) \left(\frac{3A_4}{A_2^2} - 1 \right) + 4\gamma^2 \right] (K^*)^2, \quad (\text{B.28})$$

它给出一个形如式 (B.22) 的简单加性解，其中

$$\nu = \nu(\gamma) \equiv (1 - \gamma^2) \left[(1 - \gamma^2) \left(\frac{3A_4}{A_2^2} - 1 \right) + 4\gamma^2 \right]. \quad (\text{B.29})$$

作为快速检验，当 $\gamma \rightarrow 0$ 时， ν 退化为之前对普通 MLP 得到的结果 (A.70)。更重要的是，在允许的范围 $0 < \gamma^2 < 1$ 内， $\nu(\gamma)$ 严格为正，并随 γ 增大而单调下降至 $\nu(1) = 0$ 。³²⁰

$K^* = 0$ 普适类

对 $K^* = 0$ 普适类，利用式 (B.21) 把重标度权重方差调至临界性。在这种情况下，单输入核的渐近行为会发生改变。在临界性处计算残差 MLP 的核递推关系 (B.12)，并回顾展开式 (5.83)：

$$g(K) = \sigma_1^2 [K + a_1 K^2 + O(K^3)], \quad (\text{B.30})$$

单输入核递推关系变为

$$K^{(\ell+1)} = K^{(\ell)} + a_1(1 - \gamma^2) (K^{(\ell)})^2 + \dots, \quad (\text{B.31})$$

其深层渐近行为为

$$K^{(\ell)} = \left[\frac{1}{(-a_1)(1 - \gamma^2)} \right] \frac{1}{\ell} + \dots. \quad (\text{B.32})$$

为了计算四点顶角递推关系，需要

$$\chi_{\parallel}(K) = 1 + (1 - \gamma^2) [2a_1 K + O(K^2)], \quad (\text{B.33})$$

$$\left[\langle \sigma^4 \rangle_{K^*} - \langle \sigma^2 \rangle_{K^*}^2 \right] = \sigma_1^4 [2K^2 + O(K^3)], \quad (\text{B.34})$$

第一个表达式由式 (5.121) 偏移而来，具体依据式 (B.15) 和 (B.21)；而第二个表达式则与之前的式 (5.122) 相同。代入这些表达式并匹配各项，得到

$$\nu = \nu(\gamma) \equiv \frac{2}{3}(1 - \gamma^4). \quad (\text{B.35})$$

当 $\gamma \rightarrow 0$ 时，这也退化为之前对普通 $K^* = 0$ MLP 得到的结果 (A.69)；它在允许的范围 $0 < \gamma^2 < 1$ 内同样严格为正，并随 γ 增大而单调下降至 $\nu(1) = 0$ 。因而， $K^* = 0$ 普适类的 $\nu(\gamma)$ 在定性上可与尺度不变普适类相比。

³²⁰要看出这一点，需要使用如下事实：对所有尺度不变激活函数，都有 $A_4 \geq A_2^2$ 。

最优深宽比的物理学

正如在 §A.3 末尾所看到的，按照我们的无监督学习判据，最大化 $1/n^3$ 阶互信息 (A.67)，自然给出了网络最优深宽比的估计 (A.73)。对残差 MLP，这给出

$$r^*(\gamma) \equiv \left(\frac{4}{20 + 3n_L} \right) \frac{1}{\nu(\gamma)}, \quad (\text{B.36})$$

其中，对尺度不变普适类， $\nu(\gamma)$ 由式 (B.29) 给出；对 $K^* = 0$ 普适类，则由式 (B.35) 给出。因而可以看到，对任一普适类， $\nu(\gamma)$ 的单调下降都使 $r^*(\gamma)$ 随 γ 增大而单调上升：从 $\gamma = 0$ 的普通 MLP 出发，残差 MLP 会偏好越来越大的深宽比。由此，我们实现了本节开头的理论预言：我们的有效理论形式体系支持这样一个假说，即残差连接能够解决退化问题。

下面进一步解释这一机制。文献 [90] 提出，残差连接在极深网络中的益处，在于它们让全局网络架构表现为许多较浅网络的一个集成：在这一解释中，每个特定的“浅层网络”，对应于信号在单个残差网络中沿一条从输入到输出的路径传播。研究发现，梯度主要由那些跳过网络大部分结构、仅通过少量隐藏层残差块的路径所支配。这实际上为结果 (B.36) 提供了一种有趣的理解方式：如果最大化互信息 (A.67)，是在权衡深度作为归纳偏置对神经关联 (§6.4.1) 的有益作用，与深度因涨落增长 (§5.4) 而产生的有害作用，那么这种集成自然可以在保留神经关联的同时抑制涨落。于是，利用残差连接扩展可训练网络的深度，至少在一定范围内，也应当带来更好的测试集性能。

最后请注意，式 (B.36) 其实还可以用另一种方式解释：与其在固定残差超参数 γ 时估计最优深宽比 $r^*(\gamma)$ ，不如把它看作在固定深宽比 r 时估计最优残差超参数 $\gamma^*(r)$ 。从后一视角出发，可以得到一个有趣的认识。一方面，对 $r \ll 1$ 的极浅网络，由于 $\nu(\gamma)$ 从 $\gamma = 0$ 处的最大值开始单调下降，我们的判据 (B.36) 无法满足。按照普通 MLP 的原始判据 (A.73)，这类网络比最优情形更浅，即 $r < r^*(\gamma = 0)$ ；在没有残差连接时，其互信息最大，即 $\gamma^*(r) = 0$ 。

另一方面，对 $r > r^*(\gamma = 0)$ 的极深网络，随着 r 增长，最优残差超参数 $\gamma^*(r)$ 单调趋近于 1。³²¹ 总的来说，这表明，只有当网络深宽比 r 大于普通 MLP 的最优深宽比所设定的阈值 $r^*(\gamma = 0)$ 时，才应开启残差连接。

顺带一提，如果担心大 r 时微扰理论的有效性，请注意，真正的物理展开参数由如下组合给出：

$$\frac{V^{(L)}}{n(G^{(L)})^2} = \nu(\gamma = \gamma^*(r)) \times r, \quad (\text{B.37})$$

即使深宽比 r 趋于无穷，它仍保持有限。从这个意义上说，可以利用 $\gamma^*(r)$ 任意扩展能由我们的有效理论描述的有效深网络范围。

³²¹ 设定 γ^* 时，务必同时按照式 (B.20) 或 (B.21) 调整重标度权重方差 $C_W(\gamma^*)$ ，以保持临界性。在 $r \gg r^*(\gamma = 0)$ 的极限下，最优残差超参数以 $1 - [\gamma^*(r)]^2 \sim 1/r$ 的方式趋近于一，而临界初始化则以 $C_W(\gamma = \gamma^*(r)) \sim 1/r$ 的方式变小。

B.4 残差构件

在最后一节中，我们将说明一种理论与经验相结合的方法，用来把非常一般的残差网络调至临界性。这一方法可以实际实施，以调节超越多层感知机架构的残差网络超参数。我们希望，这一讨论能为如下思路提供一个蓝图：先在小网络上进行少量简单测量，再依照我们的有效理论方法把结果扩展到更大规模，从而高效设计大得多的模型。

一般的残差网络可以这样定义：把简单的 MLP 层块 (B.3) 替换为一般的非线性残差块：

$$b_i^{(\ell+1)} + \sum_{j=1}^n W_{ij}^{(\ell+1)} \sigma_{j;\delta}^{(\ell)} \rightarrow \mathbf{R}_i \left(z_{\delta}^{(\ell)}; \theta^{(\ell+1)} \right) \equiv \mathbf{R}_{i;\delta}^{(\ell+1)}. \quad (\text{B.38})$$

这里，第 ℓ 层残差块 $\mathbf{R}_{i;\delta}^{(\ell)}$ 由模型参数 $\theta^{(\ell)}$ 塑造；应当让 $\mathbf{R}_{i;\delta}^{(\ell)}$ 在神经元指标上为方阵，即 $n_\ell = n_{\ell+1} \equiv n$ ，从而可以把残差块的输出加回预激活量。这得到如下前向方程：

$$z_{i;\delta}^{(\ell+1)} = \xi^{(\ell+1)} \mathbf{R}_i \left(z_{\delta}^{(\ell)}; \theta^{(\ell+1)} \right) + \gamma^{(\ell+1)} z_{i;\delta}^{(\ell)}, \quad (\text{B.39})$$

这里恢复了第二个残差超参数 $\xi^{(\ell)}$ ，以便缩放残差块项的整体大小。迭代方程 (B.39) 足够一般，可以示意性地涵盖许多流行的深度学习架构，包括计算机视觉的主力架构——残差卷积网络，即 **ResNet**——以及面向多头自注意力、用于语言建模的 **Transformer**。方程 (B.39) 所描述的一般残差网络中，相邻两层的两个残差块展示于图 B.1 左图。

实践中，人们在这些一般架构里采用某些启发式和特设方法，试图缓解梯度爆炸与消失问题。然而，正如由 §9.4 所知，临界性是动机充分得多的解决方案。在 §B.2 中，我们看到，对残差 MLP，可以利用残差超参数控制网络的临界性。现在来看如何为一般残差网络 (B.39) 实现某种形式的临界性。

概括而言，现在需要解决两个性质与难度均不相同的问题：

- 首先，需要确保信号能容易地通过残差块传播，尤其是对某种意义下较深的块。例如，若一个块本身由 L_R 个 MLP 层构成，即一个 $MLP-L_R$ 层块，它就会有内部版本的梯度爆炸与消失问题。理论研究者应尽力对有实际意义的这类块进行临界性分析；但如果出于某种原因不得不把残差块 $\mathbf{R}_{i;\delta}^{(\ell)}$ 当作黑箱，那么就需要做一些工程工作：应当测量一个块输出处的两点块-块相关子

$$\mathbb{E} \left[\mathbf{R}_{i_1;\delta_1}^{(\ell+1)} \mathbf{R}_{i_2;\delta_2}^{(\ell+1)} \right], \quad (\text{B.40})$$

再把它与该块输入的两点相关子

$$\mathbb{E} \left[z_{i_1;\delta_1}^{(\ell)} z_{i_2;\delta_2}^{(\ell)} \right]. \quad (\text{B.41})$$

比较。为了简洁而具体，这里只考察它们满足 $i_1 = i_2 \equiv i$ 和 $\delta_1 = \delta_2 \equiv \delta$ 的对角分量。特别地，对神经元指标 $i = 1, \dots, n$ 以及样本指标 $\delta \in \mathcal{D}$ 取平均，就能比较两个标量

$$\overline{G}_{\text{RR}}^{(\ell+1)} \equiv \frac{1}{|\mathcal{D}|n} \sum_{i=1}^n \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[\mathbf{R}_{i;\delta}^{(\ell+1)} \mathbf{R}_{i;\delta}^{(\ell+1)} \right], \quad \overline{G}_{zz}^{(\ell)} \equiv \frac{1}{|\mathcal{D}|n} \sum_{i=1}^n \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[z_{i;\delta}^{(\ell)} z_{i;\delta}^{(\ell)} \right] \quad (\text{B.42})$$

而不是两个矩阵 (B.40) 和 (B.41).³²²

建立这些测量之后, 需要调节块的初始化超参数, 使这些量具有相近的大小. 例如, 如果块的内部由许多迭代层参数化——如 MLP- L_R 层块——那么必须确保大小之差至多按深度超参数 L_R 的某个多项式增长; 重要的是, 要确保 $\overline{G}_{RR}^{(\ell+1)}/\overline{G}_{zz}^{(\ell)}$ 不存在指数增长或衰减.³²³ 注意, 在建立测量时, 测量交叉相关子

$$\overline{G}_{Rz}^{(\ell+0.5)} \equiv \frac{1}{|\mathcal{D}|n} \sum_{i=1}^n \sum_{\delta \in \mathcal{D}} \mathbb{E} \left[R_{i;\delta}^{(\ell+1)} z_{i;\delta}^{(\ell)} \right], \quad (\text{B.43})$$

也会有所帮助; 下一点会用到它.

- 现在利用前向方程 (B.39), 可以把两点相关子对角分量的递推关系写成

$$\overline{G}_{zz}^{(\ell+1)} = \gamma^2 \overline{G}_{zz}^{(\ell)} + 2\gamma\xi \overline{G}_{Rz}^{(\ell+0.5)} + \xi^2 \overline{G}_{RR}^{(\ell+1)}, \quad (\text{B.44})$$

这里略去了残差超参数上的层指标, 以使表达式简洁.³²⁴

为了保持预激活量两点相关子的这一分量, 令该方程右端等于第 ℓ 层相关子. 整理后, 所需条件为

$$(1 - \gamma^2) \overline{G}_{zz}^{(\ell)} = \xi^2 \overline{G}_{RR}^{(\ell+1)} + 2\gamma\xi \overline{G}_{Rz}^{(\ell+0.5)}. \quad (\text{B.45})$$

既然这些量都已经测得, 这个方程应当能给出残差超参数的简单解析解.³²⁵

总而言之, 这种混合方法实现了我们的一个目标: 把实验上可测的可观测量用作有效理论分析的输入. 我们希望, 类似的思维方式将来能带来设计和调节深度学习模型的强大方法.

³²²更一般地, 还应当通过对输入对取平均来计入非对角分量, 以估计 $K_{[2]}^{(\ell)}$ 的适当类似物, 参见式 (5.19). 随后还要确保这一分量的递推关系的类似物——例如式 (B.14)——得以保持. 由于这里项目符号中的讨论有些示意性, 我们把这些细节留给 *PyTorch* 文档.

³²³*Transformer* 架构所采用的层归一化 [91], 可能是解决这一问题的一种合理启发式方法. 不过, 更理想的情形是不把块当作黑箱, 而是利用块本身的某些结构来找出临界性条件.

³²⁴注意, 与 §B.2 中讨论的 MLP 单层块不同, 一般而言, 不能简单地通过重缩放 C_W 消去 ξ : 例如, 若有一个由 ReLU 激活函数构成、满足 $L_R \gg 1$ 的深 MLP- L_R 层块, 那么先令 $C_W = 2$ 、最后再调节 ξ , 或许更容易. 因而一般应当认为, 块的初始化超参数要先固定——以确保块内部的临界性——然后对每个 γ , 再按照式 (B.45) 调节 $\xi(\gamma)$, 以确保整个网络的临界性.

³²⁵相应地, 方程 (B.45) 的每个临界解 (γ, ξ) 都会给出具有不同最优深宽比 $r^*(\gamma, \xi)$ 的架构. 对特定的 (γ, ξ) , 一般残差网络的最优深宽比也可以用混合方法作类似估计: 把 §B.3 中所作的理论分析, 与对四点连通相关子的某个适当组合的测量结合起来.

参考文献

- [1] P. A. M. Dirac, *The Principles of Quantum Mechanics*. No. 27 in The International Series of Monographs on Physics. Oxford University Press, 1930.
.
- [2] J. von Neumann, *Mathematical Foundations of Quantum Mechanics*. Princeton University Press, 1955.
.
- [3] S. Carnot, *Reflections on the Motive Power of Heat and on Machines Fitted to Develop that Power*. J. Wiley, 1890. Trans. by R. H. Thurston from *Réflexions sur la puissance motrice du feu et sur les machines propres à développer cette puissance* (1824).
.
- [4] M. Bessarab, *Landau*. M., Moscow worker, 1971. Trans. by B. Hanin from the original Russian source. <http://www.ega-math.narod.ru/Landau/Dau1971.htm>.
.
- [5] J. Polchinski, “Memories of a Theoretical Physicist,” [arXiv:1708.09093](https://arxiv.org/abs/1708.09093) [[physics.hist-ph](#)].
.
- [6] F. Rosenblatt, “Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanism,” tech. rep., Cornell Aeronautical Lab, Inc., 1961.
.
- [7] W. S. McCulloch and W. Pitts, “A logical calculus of the ideas immanent in nervous activity,” *The bulletin of mathematical biophysics* **5** no. 4, (1943) 115–133.
.
- [8] F. Rosenblatt, “The perceptron: a probabilistic model for information storage and organization in the brain,” *Psychological review* **65** no. 6, (1958) 386.
.
- [9] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems*, vol. 25, pp. 1097–1105. 2012.
.
- [10] K. Fukushima, “Neocognitron: a self organizing neural network model for a mechanism of pattern recognition unaffected by shift in position,” *Biological Cybernetics* **36** no. 4, (1980) 193–202.
.

- [11] Y. LeCun, “Generalization and Network Design Strategies,” No. CRG-TR-89-4. 1989.
.
- [12] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel, “Backpropagation Applied to Handwritten Zip Code Recognition,” *Neural Computation* **1** no. 4, (1989) 541–551.
.
- [13] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE* **86** no. 11, (1998) 2278–2324.
.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is All you Need,” in *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008. 2017. [arXiv:1706.03762 \[cs.CL\]](#).
.
- [15] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning Internal Representations by Error Propagation,” in *Parallel Distributed Processing: Explorations in the Microstructure of Cognition. Volume 1: Foundations*, D. E. Rumelhart, J. L. McClelland, and the PDP Research Group, eds., ch. 8, pp. 318–362. MIT Press, Cambridge, MA, 1986.
.
- [16] Y. A. LeCun, L. Bottou, G. B. Orr, and K.-R. Müller, “Efficient backprop,” in *Neural Networks: tricks of the trade*, pp. 9–48. Springer, 1998.
.
- [17] Gallant and White, “[There exists a neural network that does not make avoidable mistakes](#),” in *IEEE 1988 International Conference on Neural Networks*, pp. 657–664 vol.1. 1988.
.
- [18] V. Nair and G. E. Hinton, “Rectified Linear Units Improve Restricted Boltzmann Machines,” in *International Conference on Machine Learning*. 2010.
.
- [19] X. Glorot, A. Bordes, and Y. Bengio, “Deep Sparse Rectifier Neural Networks,” in *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, pp. 315–323, JMLR Workshop and Conference Proceedings. 2011.
.

- [20] A. L. Maas, A. Y. Hannun, and A. Y. Ng, “Rectifier nonlinearities improve neural network acoustic models,” in *ICML Workshop on Deep Learning for Audio, Speech, and Language Processing*. 2013.
.
- [21] C. Dugas, Y. Bengio, F. Bélisle, C. Nadeau, and R. Garcia, “Incorporating Second-Order Functional Knowledge for Better Option Pricing,” in *Advances in Neural Information Processing Systems*, vol. 13, pp. 472–478. 2000.
.
- [22] P. Ramachandran, B. Zoph, and Q. V. Le, “Searching for Activation Functions,” [arXiv:1710.05941 \[cs.NE\]](#).
.
- [23] D. Hendrycks and K. Gimpel, “Gaussian Error Linear Units (GELUs),” [arXiv:1606.08415 \[cs.LG\]](#).
.
- [24] A. M. Turing, “The chemical basis of morphogenesis,” *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences* **237** no. 641, (1952) 37–72.
.
- [25] A. M. Saxe, J. L. McClelland, and S. Ganguli, “Exact solutions to the nonlinear dynamics of learning in deep linear neural networks,” [arXiv:1312.6120 \[cs.NE\]](#).
.
- [26] J. A. Zavatone-Veth and C. Pehlevan, “Exact priors of finite neural networks,” [arXiv:2104.11734 \[cs.LG\]](#).
.
- [27] J. McGreevy, “Holographic duality with a view toward many-body physics,” *Adv. High Energy Phys.* **2010** (2010) 723105, [arXiv:0909.0518 \[hep-th\]](#).
.
- [28] R. M. Neal, “Priors for infinite networks,” in *Bayesian Learning for Neural Networks*, pp. 29–53. Springer, 1996.
.
- [29] J. Lee, Y. Bahri, R. Novak, S. S. Schoenholz, J. Pennington, and J. Sohl-Dickstein, “Deep Neural Networks as Gaussian Processes,” in *International Conference on Learning Representations*. 2018. [arXiv:1711.00165 \[stat.ML\]](#).
.

- [30] A. G. de G. Matthews, M. Rowland, J. Hron, R. E. Turner, and Z. Ghahramani, “Gaussian Process Behaviour in Wide Deep Neural Networks,” in *International Conference on Learning Representations*. 2018. [arXiv:1804.11271 \[stat.ML\]](#).
.
- [31] S. Yaida, “Non-Gaussian Processes and Neural Networks at Finite Widths,” in *Mathematical and Scientific Machine Learning Conference*. 2020.
[arXiv:1910.00019 \[stat.ML\]](#).
.
- [32] F. J. Dyson, “The S Matrix in Quantum Electrodynamics,” *Phys. Rev.* **75** (Jun, 1949) 1736–1755.
.
- [33] J. Schwinger, “On the Green’s functions of quantized fields. I,” *Proceedings of the National Academy of Sciences* **37** no. 7, (1951) 452–455.
.
- [34] M. D. Zeiler and R. Fergus, “Visualizing and Understanding Convolutional Networks,” in *Computer Vision – ECCV 2014*, pp. 818–833. 2014.
.
- [35] A. Rahimi and B. Recht, “Random Features for Large-Scale Kernel Machines,” in *Advances in Neural Information Processing Systems*, vol. 20, pp. 1177–1184. 2008.
.
- [36] J. Devlin, M. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” [arXiv:1810.04805 \[cs.CL\]](#).
.
- [37] M. Gell-Mann and F. E. Low, “Quantum Electrodynamics at Small Distances,” *Phys. Rev.* **95** (Sep, 1954) 1300–1312.
.
- [38] K. G. Wilson, “Renormalization Group and Critical Phenomena. I. Renormalization Group and the Kadanoff Scaling Picture,” *Phys. Rev. B* **4** (Nov, 1971) 3174–3183.
.
- [39] K. G. Wilson, “Renormalization Group and Critical Phenomena. II. Phase-Space Cell Analysis of Critical Behavior,” *Phys. Rev. B* **4** (Nov, 1971) 3184–3205.
.

- [40] E. C. G. Stueckelberg de Breidenbach and A. Petermann, “Normalization of constants in the quanta theory,” *Helv. Phys. Acta* **26** (1953) 499–520.
.
- [41] N. Goldenfeld, *Lectures on phase transitions and the renormalization group*. CRC Press, 2018.
.
- [42] J. Cardy, *Scaling and Renormalization in Statistical Physics*. Cambridge Lecture Notes in Physics. Cambridge University Press, 1996.
.
- [43] M. Minsky and S. A. Papert, *Perceptrons: An Introduction to Computational Geometry*. MIT Press, 1988.
.
- [44] S. Coleman, *Aspects of Symmetry: Selected Erice Lectures*. Cambridge University Press, Cambridge, U.K., 1985.
.
- [45] B. Poole, S. Lahiri, M. Raghu, J. Sohl-Dickstein, and S. Ganguli, “Exponential Expressivity in Deep Neural Networks Through Transient Chaos,” in *Advances in Neural Information Processing Systems*, vol. 29, pp. 3360–3368. 2016.
[arXiv:1606.05340](#) [stat.ML].
.
- [46] M. Raghu, B. Poole, J. Kleinberg, S. Ganguli, and J. Sohl-Dickstein, “On the Expressive Power of Deep Neural Networks,” in *International Conference on Machine Learning*, pp. 2847–2854. 2017. [arXiv:1606.05336](#) [stat.ML].
.
- [47] S. S. Schoenholz, J. Gilmer, S. Ganguli, and J. Sohl-Dickstein, “Deep Information Propagation,” in *5th International Conference on Learning Representations*. 2017.
[arXiv:1611.01232](#) [stat.ML].
.
- [48] K. He, X. Zhang, S. Ren, and J. Sun, “Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification,” in *Proceedings of the IEEE international conference on computer vision*, pp. 1026–1034. 2015.
[arXiv:1502.01852](#) [cs.CV].
.
- [49] L. Kadanoff, “Critical Behavior. Universality and Scaling,” in *Proceedings of the International School of Physics Enrico Fermi, Course LI (27 July –8 August 1970)*. 1971.

- .
- [50] E. T. Jaynes, *Probability Theory: The Logic of Science*. Cambridge University Press, 2003.
- .
- [51] L. Froidmont, *On Christian Philosophy of the Soul*. 1649.
- .
- [52] D. J. MacKay, “Probable networks and plausible predictions—a review of practical Bayesian methods for supervised neural networks,” *Network: computation in neural systems* **6** no. 3, (1995) 469–505.
- .
- [53] C. K. I. Williams, “Computing with Infinite Networks,” in *Advances in Neural Information Processing Systems*, vol. 9, p. 295–301. 1996.
- .
- [54] G. Hinton, O. Vinyals, and J. Dean, “Distilling the Knowledge in a Neural Network,” in *NIPS Deep Learning and Representation Learning Workshop*. 2015. [arXiv:1503.02531 \[stat.ML\]](#).
- .
- [55] D. Hebb, *The Organization of Behavior: A Neuropsychological Theory*. Taylor & Francis, 2005.
- .
- [56] S. Coleman, “Sidney Coleman’s Dirac Lecture ‘Quantum Mechanics in Your Face’,” [arXiv:2011.12671 \[physics.hist-ph\]](#).
- .
- [57] A. Jacot, F. Gabriel, and C. Hongler, “Neural tangent kernel: Convergence and generalization in neural networks,” in *Advances in Neural Information Processing Systems*, vol. 31, pp. 8571–8580. 2018. [arXiv:1806.07572 \[cs.LG\]](#).
- .
- [58] S. Hochreiter, *Untersuchungen zu dynamischen neuronalen Netzen*. Diploma, Technische Universität München, 1991.
- .
- [59] Y. Bengio, P. Frasconi, and P. Simard, “The problem of learning long-term dependencies in recurrent networks,” in *IEEE International Conference on Neural Networks*, vol. 3, pp. 1183–1188, IEEE. 1993.
- .

- [60] R. Pascanu, T. Mikolov, and Y. Bengio, “On the difficulty of training Recurrent Neural Networks,” in *International Conference on Machine Learning*, pp. 1310–1318, PMLR. 2013. [arXiv:1211.5063 \[cs.LG\]](#).
.
- [61] M. Kline, *Mathematical Thought From Ancient to Modern Times: Volume 3*. Oxford University Press, 1990.
.
- [62] J. Lee, L. Xiao, S. Schoenholz, Y. Bahri, R. Novak, J. Sohl-Dickstein, and J. Pennington, “Wide Neural Networks of Any Depth Evolve as Linear Models Under Gradient Descent,” in *Advances in Neural Information Processing Systems*, vol. 32, pp. 8572–8583. 2019. [arXiv:1902.06720 \[stat.ML\]](#).
.
- [63] E. Fix and J. Hodges, “Discriminatory Analysis. Nonparametric Discrimination: Consistency Properties,” *USAF School of Aviation Medicine, Project Number: 21-49-004, Report Number: 4* (1951) .
.
- [64] T. Cover and P. Hart, “Nearest neighbor pattern classification,” *IEEE Trans. Inf. Theory* **13** (1967) 21–27.
.
- [65] A. Einstein, “On the Method of Theoretical Physics,” *Philosophy of Science* **1** no. 2, (1934) 163–169.
.
- [66] B. Hanin and M. Nica, “Finite Depth and Width Corrections to the Neural Tangent Kernel,” in *International Conference on Learning Representations*. 2020. [arXiv:1909.05989 \[cs.LG\]](#).
.
- [67] E. Dyer and G. Gur-Ari, “Asymptotics of Wide Networks from Feynman Diagrams,” in *International Conference on Learning Representations*. 2020. [arXiv:1909.11304 \[cs.LG\]](#).
.
- [68] G. F. Giudice, “Naturally Speaking: The Naturalness Criterion and Physics at the LHC,” [arXiv:0801.2562 \[hep-ph\]](#).
.
- [69] F. J. Dyson, “Forward,” in *Classic Feynman: All the Adventures of a Curious Character*, R. Leighton, ed., pp. 5–9. W. W. Norton & Company Ltd., 2006.
.

- [70] L. Chizat, E. Oyallon, and F. Bach, “On Lazy Training in Differentiable Programming,” in *Advances in Neural Information Processing Systems*, vol. 32. 2019. [arXiv:1812.07956](#) [math.OC].
- .
- [71] D. J. MacKay, *Information Theory, Inference and Learning Algorithms*. Cambridge University Press, 2003.
- .
- [72] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, and D. Amodei, “Scaling laws for neural language models,” [arXiv:2001.08361](#) [cs.LG].
- .
- [73] C. Zhang, S. Bengio, M. Hardt, B. Recht, and O. Vinyals, “Understanding deep learning requires rethinking generalization,” [arXiv:1611.03530](#) [cs.LG].
- .
- [74] D. H. Wolpert, “The lack of a priori distinctions between learning algorithms,” *Neural computation* **8** no. 7, (1996) 1341–1390.
- .
- [75] D. H. Wolpert and W. G. Macready, “No free lunch theorems for optimization,” *IEEE transactions on evolutionary computation* **1** no. 1, (1997) 67–82.
- .
- [76] L. Boltzmann, “On Certain Questions of the Theory of Gases,” *Nature* **51** no. 1322, (1895) 413–415.
- .
- [77] L. Boltzmann, *Lectures on Gas Theory*. Berkeley, University of California Press, 1964. Trans. by S. G. Brush from *Vorlesungen ueber Gastheorie* (2 vols., 1896 & 1898).
- .
- [78] C. E. Shannon, “A mathematical theory of communication,” *The Bell System Technical Journal* **27** no. 3, (1948) 379–423.
- .
- [79] C. E. Shannon, “A mathematical theory of communication,” *The Bell System Technical Journal* **27** no. 4, (1948) 623–656.
- .
- [80] E. T. Jaynes, “Information Theory and Statistical Mechanics,” *Phys. Rev.* **106** (May, 1957) 620–630.
- .

- [81] E. T. Jaynes, “Information Theory and Statistical Mechanics. II,” *Phys. Rev.* **108** (Oct, 1957) 171–190.
.
- [82] Y. LeCun, J. Denker, and S. Solla, “Optimal Brain Damage,” in *Advances in Neural Information Processing Systems*, vol. 2. Morgan-Kaufmann, 1990.
.
- [83] J. Frankle and M. Carbin, “The Lottery Ticket Hypothesis: Finding Sparse, Trainable Neural Networks,” in *International Conference on Learning Representations*. 2019. [arXiv:1803.03635](#) [cs.LG].
.
- [84] T. Banks and A. Zaks, “On the phase structure of vector-like gauge theories with massless fermions,” *Nuclear Physics B* **196** no. 2, (1982) 189–204.
.
- [85] R. Linsker, “Self-organization in a perceptual network,” *Computer* **21** no. 3, (1988) 105–117.
.
- [86] S. Becker and G. E. Hinton, “Self-organizing neural network that discovers surfaces in random-dot stereograms,” *Nature* **355** no. 6356, (1992) 161–163.
.
- [87] B. Gale, R. Zemeckis, M. J. Fox, and C. Lloyd, *Back to the Future Part II*. Universal Pictures, 1989.
.
- [88] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778. 2016.
.
- [89] S. Ioffe and C. Szegedy, “Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift,” in *International Conference on Machine Learning*, pp. 448–456. 2015. [arXiv:1502.03167](#) [cs.LG].
.
- [90] A. Veit, M. Wilber, and S. Belongie, “Residual Networks Behave Like Ensembles of Relatively Shallow Networks,” in *Advances in Neural Information Processing Systems*, vol. 30, pp. 550–558. 2016. [arXiv:1605.06431](#) [cs.CV].
.

- [91] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer Normalization,” in *Deep Learning Symposium, Neural Information Processing Systems*. 2016. [arXiv:1607.06450](#) [stat.ML].

索引

- $1/n$ expansion, 25, 160, 165, 178, 181, 252, 276, 314
- $1/n$ 展开, 7, 8, 49, 51, 56, 74, 75, 80–82, 109, 114, 122, 129, 132, 164, 174, 180, 276, 313
- *-polation, 218, 219, 220, 324
 - curvature, 221
 - deep linear networks, 218
 - nonlinear networks, 219, 221
 - same for inter- and extra-, 222
- δ expansion, 212, 216
 - generalized to $\epsilon_{1,2}$ expansion, 220
- δ 展开, 92
- $\gamma^{[a]}$ basis
 - $\sigma\sigma$, 213
 - $\sigma'\sigma'$, 213
 - frozen NTK, 214
 - kernel, 135, 212, 324
 - for hybrid approach, 345
 - output matrix, 136
- $\gamma^{[a]}$ 基底, 91
 - $\sigma\sigma$, 96
- absolute certainty
 - *-polation, 222
- action, 26
 - quadratic, *see also* Gaussian distribution, 22, 161
 - quartic, 23, *see also* nearly-Gaussian distribution, 23, 24, 25, 27
 - sextic, 313
 - truncation, 27, *see also* hierarchical scaling
- activation function, 193
 - GELU, 37, 90, 104, 107, 108, 264, 272, 303
 - leaky ReLU, 35, 36
 - linear, 36, 42, 43, 88, 98, 99, 109, 111, 116, 119, 120, 184, 218, 228, 273, 332
 - perceptron, 34, 36, 101
 - ReLU, 36, 37, 88, 92, 98, 99, 102, 107, 108, 110, 111, 113, 117–119, 184, 189, 193, 194, 264, 272, 303, 313, 332, 333, 345
 - sigmoid, 34, 36, 100–102, 193
 - sin, 36, 90, 104, 107, 187–190, 194, 215
 - softplus, 37, 102, 104, 105, 107, 108
 - SWISH, 37, 90, 100, 104, 107, 108, 264, 272, 303
 - tanh, 34, 36, 90, 100–105, 107, 108, 112, 113, 135, 187–190, 193, 194, 215, 270, 333
- algorithm independence, 304
- algorithm projector, 258, 265, 295, 296, 297, 301, 303, 304, 312
- Anderson, Thomas A. “Neo”, 17
- applause, 141
- Armstrong, Neil, 199
- artificial neuron, 141
- backward equation
 - MLP, 160, 198
- Banks-Zaks fixed point, *see* fixed point
- batch, *see also* stochastic gradient descent
- Bayes, Reverend Thomas, 129
- Bayesian inference
 - connection to linear models, 227
 - evidence, 124, 126, 127, 131, 133–136, 321
 - relation to generalization error, 211
- hierarchical modeling, 131
- hypothesis, *see* hypothesis (Bayesian inference)
- likelihood, 124, 126–128, 131, 132, 140, 146, 147

- model comparison, 124, 125, 131, **131**, 132–134, 136, 318, 321
 - Bayes' factor, **131**, 132, 133, 135, 318, 321
- model fitting, 124, 125, 127, **128**, 130–132, 152, 205, 207
 - approximation methods, 128
 - exact marginalization, 129
- posterior, *see* posterior
- practicalities, 140, 146
- prediction, **128**, 130, 131
- prior, *see* prior
- via gradient descent
 - at infinite width, 208
 - but not at finite width, 304
- wiring
 - finite width, 144
 - infinite width, 141
- Bayesian probability
 - Bayes' rule, 126, 129–131, 133, 140, 146, 150
 - hypothesis, *see* hypothesis (Bayesian inference)
 - product rule, 125
 - statements, 123, 124
 - sum rule, 125
- bell curve, *see also* Gaussian function
- bias-variance decomposition, *see also* generalization error
- bias-variance tradeoff, 152
 - for a universality class
 - $K^* = 0$ activations, 214
 - scale-invariant activations, 216
 - generalized, 210, 216
 - vs. standard, 210
 - relation to criticality, 212
- biological neuron, 141
- bit (unit of entropy), 317
- Boltzmann entropy, *see* entropy
- Boltzmann 分布, 326
- Boltzmann 常数, 317
- Boltzmann, Ludwig, 2, 316
- bra-ket notation, 22, *see also* Gaussian expectation
- Brown, Emmett Lathrop “Doc”, 335
- Carnot, Sadi, 2
- chain rule, 157, 160
- chain-rule factor, 160, 192
- classification, 140, **151**
- CNN, *see* 卷积神经网络
- cokurtosis, *see* kurtosis, excess
- Coleman, Sidney, 150, 156
- complete the square, 15, 139, 167
- connected correlator, **19**, 27, 179, 314
 - four-point, *see also* four-point vertex, *see also* kurtosis, excess, **19**, 23, 25, 143, 162
 - general definition, 19
 - higher-point, 27
 - odd-point vanish with parity, 19
 - one-point, 19, *see also* mean
 - relation to nearly-Gaussian distributions, 21
 - two-point, 19, *see also* covariance, *see also* metric
- continuum limit, *see* gradient descent
- convex function, 319
- ConvNet, *see* 卷积神经网络
- convolutional neural network, 125, 131, 133, 337
- correlator
 - M -point, 18
 - connected, *see* connected correlator
 - four-point, 162, 164
 - full, 19, *see also* moment
 - two-point, 162, 164
- coupling, 9
 - non-Gaussian, 26, 27
 - quadratic, 27, 142–144, 165
 - quartic, 23, 25, 27, 142–144, 146, 165, 329

- sextic, 313, 329
- covariance, 13, *see also* cumulant
- critical exponent, 186, 190
- criticality, 245, 247
 - as unsupervised learning, 333
 - principle of, 215, 217, 284
- cross correlation
 - dNTK-preactivation, 239
 - P -recursion, 242
 - Q -recursion, 243
 - NTK-preactivation, 164–166, 170, 170, 171, 173, 174, 178, 179, 183, 190
 - D -recursion, 172
 - F -recursion, 173
- cross-entropy loss, *see* loss
- cubic model, *see* nonlinear model
- cumulant, *see also* connected correlator, 19, 326
 - first (mean), 19, *see also* mean
 - general definition, 19
 - second (covariance), 19, *see also* covariance
- cutoff, effective theory, 183, 230, 246, 302, 314, 322
 - nearly-kernel methods, 261
 - vs. measurement precision, 321
- data distribution, *see also* input data
- data-dependent coupling, 130, 132, 179, 310–314
- ddNTK, 264, 265, 266
- ddNTKs
 - contribution to finite-width prediction, 300
 - full expressions, 305
 - scaling laws, 269
 - statistics, 267
 - R -recursion, 268, 307
 - S -recursion, 268, 307
 - T -recursion, 268, 308
 - U -recursion, 268, 308
 - step-independence, 283
- deep learning
 - abstracted, 251
- deep linear network, 191, 218, 314
 - limitations, 218
- deformation
 - Gaussian distribution, 23, 26, 326, 327
 - linear model, 251
 - quadratic model, 262
- defrosted NTK, *see* neural tangent kernel
- degradation problem, 335, *see also* overly
 - deep, *see also* residual network, 335, 337, 340, 340
- diagonalization, 26
- difference equation, *see also* training dynamics
 - linear, 283, 285
 - homogeneous, 283
 - inhomogeneous, 289
 - nonlinear, 283
- differential of the neural tangent kernel, *see also* meta kernel, 230, 231, 267
- connection to representation learning, 260
- dNTK-preactivation cross correlation, *see* cross correlation
- dynamical, *see* dynamical dNTK
- iteration equation, 233, *see also* forward equation
- name, 232
- scaling laws, 246
- dimensional analysis, 27, 27, 321
- Dirac delta function, 127, 135
- Dirac delta 函数, 40, 41, 60, 63, 94, 161, 166, 311
 - 积分表示, 40, 60
- Dirac, Paul Adrien Maurice, i, ii, 150, 156
- discriminative model, 151, *see also* probabilistic model
- disorder, *see* entropy
- distillation, *see* knowledge distillation

- dNTK, *see* differential of the neural tangent kernel
- Don't Panic, HHGTTG, 146
- duality, 224–226, 228, 256, 259, **313**
 - learning algorithm – algorithm projectors, 304
 - linear model – kernel methods, 222
 - microscopic-macroscopic, 309, **313**, 335
 - nonlinear model – nearly-kernel methods, 251
- dynamical dNTK, 252, 286, 292
- dynamical NTK, 250, *see also* effective kernel, *see also* interaction NTK, 272, 283, 285
- dynamics, *see* training dynamics
- Eames (*Inception* meme), 131
- early stopping, *see* regularization
- effective feature function, *see* feature function
- effective kernel, *see* nearly-kernel methods
- effective theory, 159, 188, 344
 - representation learning, 277
- effectively deep, 265, 316, 334, 343
 - range extended by residual connections, 337
- eigenvalue, 14
- eightfold way, *see also* Gell-Mann, Murray
- Einstein 求和约定, 15
- Einstein, Albert, 229
- end of training, 264, 316
- ensemble, 343
- entropy
 - additivity, 318, 319, 329
 - subadditivity, 319, 320, 333
 - as a measure of disorder, 317
 - Boltzmann entropy, 318
 - Gibbs entropy, 318
 - next-to-leading-order correction, 330
 - Shannon entropy, 317
- epoch, *see also* stochastic gradient descent
- equivalence principle, 205, 284
 - connection to generalization, 215, 217
- error factor
 - ℓ -th-layer, 231, 265
 - cross-entropy loss, 197
 - MSE loss, 154
- evidence, *see* Bayesian inference
- expectation value, 9, **11**, 17, 179
- exploding and vanishing gradient problem, 137, 191, 193
 - connection to generalization, 216
 - for residual networks, 344
 - relation to criticality, 192
- exploding and vanishing kernel problem, 191
- extensivity
 - of entropy, **319**, 323
 - of loss, 128, 152, 211
- extrapolation, *see also* *-polation
- Facebook AI Research, ii, 140
- FAIR, *see* Facebook AI Research
- FCN, *see* 全连接网络
- feature, 146, 157, 209, 278, 280, 309
 - vs. feature function, 227
- feature function, **223**, 227, 263, 304
 - effective, **252**, 256, 277
 - feature engineering for abstract inputs, **223**
 - meta, *see* meta feature function
 - meta-meta, *see* meta-meta feature function
 - nonlinear model, 251
 - random, 226–228, 311
- feature indices, 251
- feedforward network, 143
- Feynman, Richard, 9
- fine tuning, **256**
- finite-width prediction
 - Bayesian inference, 145
 - gradient descent, 296, *see also* T-shirt

- equation
- fixed point
 - Banks-Zaks, 333, *see also* optimal aspect ratio
 - nontrivial, 134
 - trivial, 134, 136
- float, *see* type (data)
- fluctuations, 19, 162
 - vs. representation learning, 302
- for your information, 333
- force, *see* Newton's second law
- forward equation
 - ddNTKs, 305, 306
 - dNTK, 235
 - general residual network, 344
 - MLP preactivations, 156, 158, 160–162, 236
 - NTK, 156, 158–160, 162, 166, 169, 170, 192, 193
 - residual MLP preactivations, 338
- four-point vertex
 - residual MLPs, 341
- Fourier 变换, 18
- frozen NTK, 180, 180, 181, 183–185, 188, 189, 192, 193, 196, 200, 204, 208, 211, 213, 216, 218, 226, 246, 248, 276
 - δ expansion, *see* δ expansion
 - $\epsilon_{1,2}$ expansion, *see* δ expansion
 - features, 227
 - infinite-width limit of the NTK, 180
 - midpoint, 212, 214, 215
 - polar angle parameterization, 216
- full correlator, *see* correlator
- fully-trained condition
 - finite width, 274
 - infinite width, 200
- function approximation, 150, 154, 155
 - for linear models, 222
- Gauss, Carl Friedrich, 195
- Gaussian distribution, 10, 27, 165, 314, 318
 - action, 22
 - as a Gaussian process, 314
 - entropy, 323, 324
 - multivariable, 14
 - normal distribution, standard, 10
 - single-variable, 10
 - zero-mean, defined by variance, 18
- Gaussian expectation, *see also* bra-ket notation, 22, 145, 162, 168, 169, 172, 173, 180, 181, 185–187, 326
- Gaussian process, *see* Gaussian distribution
- Gaussian 期望, 216
- GELU, *see* 激活函数
- general relativity, 133, 201
- generalization, 132, 155, 209
- generalization error, 309
 - bias, 210–213, 301, 303
 - related to *-polation, 221
 - exact Bayesian inference, 213
 - finite-width, 301, 304
 - optimal hyperparameter tuning, 215
 - robustness measure, 211, 212
 - universality class analysis, 212
 - variance, 210, 212, 214, 302
- generalized posterior distribution, *see* posterior distribution
- giant leap, 199, *see also* small step
- Gibbs distribution, *see* Boltzmann distribution
- Gibbs entropy, *see* entropy
- Gibbs, J. Willard, 2
- glasses (Bayesian), 133
- GPU, *see* 图形处理器
- gradient clipping, *see also* exploding and vanishing gradient problem
- gradient descent, 143, 153, 161, 192, 193, 199
 - as Bayesian inference
 - at infinite width, 208

- but not at finite width, 304
- continuum or ODE limit, 204, 284, 295, 301, 303
- model fitting, 151, 152
- stochastic, *see* stochastic gradient descent
- tensorial, 153, 159, 200
- wiring
 - finite width, 277, 278, 300
 - infinite width, 197
- gradient-based learning, *see* gradient descent
- Hamilton 算子, 284
- Hamiltonian, *see also* neural tangent kernel
- hat (occupational), 317
- Hebb 学习, 123, *see also* 神经关联, 141, 141, 143, 300
- Hebb, Donald, 141
- Hessian 矩阵, 5, 210
- hierarchical scaling, 27
- Hinton, Geoffrey Everest, 179
- Hopfield 网络, 143
- Hubbard–Stratonovich 变换, 60, 167
- hyperparameters
 - regularization, *see* regularization hyperparameters
 - scaling in an effective theory, 160
- Hyperparameters, 125, *see also* hypothesis (Bayesian inference)
- hypothesis (Bayesian inference), 123, 124, 125, 132
 - categorical, 126, *see also* cross-entropy loss, *see also* softmax distribution, 127, 205
 - deterministic, 126, *see also* Dirac delta function, 127
 - meta hypothesis, *see* meta hypothesis uncertain, 126, *see also* Gaussian distribution, *see also* mean squared error, 127, 205
 - imaginary time, 284
- indices
 - feature, *see* feature indices
 - layer, *see* layer indices
 - neural, *see* neural indices
 - sample, *see* sample indices
 - vectorial, *see* vectorial indices
- inductive bias
 - for representation learning in nonlinear models, 255
 - of activation functions, 218, 221
 - of learning algorithms, 265, *see also* algorithm projector, 295, 303, 304
 - of model architectures, 263
 - of sparsity in deep learning, 315
- infinite-width limit
 - connection to linear models, 228
 - of residual MLPs, 339
- infinity, 195
- InfoMax principle, 333, *see also* unsupervised learning
- InfoMax 原理, 333
- information, *see also* surprisal
- information theory, 303, 315
 - perspective on *-polation, 324
 - perspective on criticality, 324
 - perspective on generalization, 324
- initialization (of you), 316
- initialization distribution, 156, 157, 166, 337
- initialization hyperparameters, 129, 209
 - critical, 337
 - for residual networks, 339
- input data, 125, 133, 134, 144, 154, 157, 205, 223, 279, 312, 314, 329
- int, *see* type (data)
- integrating out, 129–131, 166, 167, 174, 309
- integration by parts, 181
- intensity (of loss), 152
- interacting theory, *see also* non-Gaussian distribution

- entropy and mutual information, 325
 - variational method, 330
- interaction NTK, 285
- interactions, 26, 143, 146, 162, 319, 320
 - connection to statistical (in)dependence, 25
 - dynamics, 253, 284, 285
 - weakly-interacting, 253
 - nearly-kernel methods, 259
 - self-interactions, 26
 - strong coupling, 314
- interlayer correlation, 165, 166, 168, 198, 199, 238
 - for dNTK evaluation, 238
- interpolation, *see also* *-polation
- inverse algorithm design, *see also* algorithm projector
- Jaynes, Edwin T., 122, 123, 326
- Jensen 不等式, 319, 320
- Johnny B. Goode, 335
- joules per kelvin (unit of entropy), 317
- k -nearest neighbors, *see* kernel methods
- Kaiming 初始化, 99, *see also* 初始化超参数
- kernel, 181
 - effective kernel, *see* nearly-kernel methods
 - kernel matrix
 - diagonal, 216
 - polar angle parameterization, 216
 - meta kernel, *see* nearly-kernel methods
 - NTK, *see* neural tangent kernel
 - trained kernel, *see* nearly-kernel methods
- kernel machine, *see* kernel methods
- kernel methods, 251
 - k -nearest neighbors, 226
 - as a memory-based method, 226
 - feature, *see* feature function
 - kernel, 224, 260, 304
 - Gaussian, 225
 - linear, 224
 - stochastic, 228
- kernel trick, 226
- prediction, 206, 226, 260, 298, 300
 - as a linear model, 222
- stochastic kernel, 227, *see also* random feature model
- kernel trick, *see* kernel methods
- KL divergence, *see* Kullback–Leibler divergence
- Konami Code, 133
- Kronecker delta, 13, 38, 40, 45, 48, 52, 134, 153, 155, 163, 174, 318
- Kullback–Leibler divergence, 205, 319, 320
- kurtosis, excess, 19, *see also* connected correlator, 143
- cokurtosis, 143
- label
 - hard, 205, *see also* one-hot encoding
 - soft, 205
- label smoothing, *see* regularization
- Landau, Lev, 3
- language model, 337, 344
- Laplace 变换, 18
- Laplace’s principle of indifference, 318
- large- n expansion, *see* $1/n$ expansion
- leaky ReLU, *see* 激活函数
- learning algorithm, 129, 150, 153, 207
 - dual to algorithm projector, 304
- learning rate, 153, 155, 185, 188, 189
 - global, 152, 153, 157, 159, 197, 200, 201, 312
 - step-dependent, 203
- learning-rate tensor, 153, 156–159, 200, 201, 204, 230, 265, 278
- layer-diagonal, 157
- layer-independence, 231
- learning rate equivalence principle, *see* equivalence principle

- likelihood, *see* Bayesian inference
- linear, *see* 激活函数
- linear model, 228
 - for effective features, 252
 - is not a deep linear network, 228
- linear regression, *see also* linear model
 - vs. quadratic regression, 253
- linear transformations, 218
- logistic 函数, 34, *see also* softmax 分布, 37, 101, 126
- loss
 - algorithm dependence at finite width, 296
 - auxiliary, 127
 - comparison of MSE and cross-entropy, 205
 - cross-entropy, 127, 192, 197, 204–206, 211, 320
 - MSE, 127, 151, 154, 159, 192, 197, 200, 201, 204, 210, 211, 278
 - for linear models, 223
 - generalized, 201, 278
 - name, 152
 - nonlinear models, 253
 - of generality, 209
 - SE, 152
 - test loss, 152, 154, 155, 210
 - relation to generalization, 209
 - training loss, 152, 152, 153–155
 - relation to overfitting, 209
 - relation to underfitting, 209
- machine learning, 150
- MacKay, David, 132, 309
- macroscopic perspective, 313, 316, 318
- magic trick, 271
- MAP, *see* maximum a posteriori
- marginal (RG flow), 276
- marginalization rule, 124
- marginalizing over, 130, 131, 166
- maximum a posteriori, 129, 131
 - gradient descent approximation, 207
- maximum entropy, principle, 316, 318, 326, 332
- maximum likelihood estimation, 129, 131, 140, 152
 - gradient descent approximation, 207
- Maxwell, James Clerk, 2
- McFly, Martin Seamus “Marty”, 335
- McGreevy, John, 56
- mean, 11, *see also* cumulant, *see also* moment
- mean squared error, *see* loss
- measurement precision cutoff, *see* cutoff
- mechanics (physics), 150
- memory-based method, *see* kernel methods, *see* nearly-kernel methods
- meta feature function, 252, 263
 - dynamical, 264
 - random, 261
- meta kernel, *see* nearly-kernel methods
- meta representation learning, *see* representation learning
- meta-meta feature function, 252, 262
- metric
 - next-to-leading-order correction, 276
 - stochastic, 227
- microscopic perspective, 313, 316, 318
- microstate (statistical mechanics), 326
- midpoint input, 212
- mini-batch, *see* batch
- minimal model
 - of representation learning, *see* representation learning
- Minsky, Marvin, 87, 179
- MLE, *see* maximum likelihood estimation
- MLP, *see* 多层感知机
- mode, 128, *see also* maximum a posteriori
- model comparison
 - Bayesian, *see* Bayesian inference
 - linear model vs. quadratic model, 255
- model fitting, *see also* training

- Bayesian, *see* Bayesian inference
- gradient-based optimization, *see* gradient descent
- model parameters, 154
- residual network, 344
- moment, *see also* full correlator, 11, 12, 15–17, 18, 19, 179
- MSE, *see* mean squared error
- MSE loss, *see* loss
- multilayer perceptron, 125, 131, 133, 179, 191
 - beyond, 344
 - vanilla, 337–339
 - with residual connections, 336, 338, 340, 344
- mutual information, 340
 - next-to-leading-order correction, 330
- Narrator (*Arrested Development*), 131
- nat (unit of entropy), 317
- natural language processing, 309, 344
- naturalness, 256, *see also* fine tuning
- near-sparsity, *see* sparsity, principle of
- nearly-Gaussian distribution, 9, 19, 25–27, 144, 165, 314, 316, 318, 325, 326
 - action, 26
 - as a nearly-Gaussian process, 314
 - connected correlators as observables, 21
 - entropy, 325
- nearly-Gaussian process, *see* nearly-Gaussian distribution
- nearly-kernel machine, *see* nearly-kernel methods
- nearly-kernel methods
 - as a memory-based method, 259
 - effective kernel, 259–262
 - in terms of effective feature functions, 261
 - relation to dynamical NTK, 262
 - kernel, 257
 - meta kernel, 258
 - other potential names, 258
 - prediction, 259
 - trained kernel, *see also* trained NTK, 260, 297
 - prediction, 260
 - wiring, 260
- nearly-linear model, *see* nonlinear model
- nearly-linear regression, *see* quadratic regression
- negative log probability, *see* action
- negative log-likelihood, *see also* loss
- neural indices, 154
- neural network, 150, 151, 191, 309, 315
- neural tangent kernel, 159, 179
 - agitated, 180, 186, 189, 190
 - defined in conjunction with dNTK, 231
 - defrosted, 180
 - dynamical, *see* dynamical NTK
 - dynamics, 286
 - first-layer, 161, 162
 - frozen, *see* frozen NTK
 - interaction, *see* interaction NTK
 - ℓ -th-layer, 157, 158, 165, 169, 172
 - mean, 165, 169, 170, 170, 172, 175, 177–181, 185, 188, 189, 192
 - next-to-leading-order correction, 276
 - name, 154, 180, 284
 - NTK-preactivation cross correlation, *see* cross correlation
 - second-layer, 162, 163
 - step-independent, 283, 290
 - trained, *see also* trained kernel, 298
 - variance, 162–165, 173, 174, 174, 175, 178, 179, 183, 190
 - A-recursion, 176
 - B-recursion, 175
- Newton tensor, *see also* second-order update
 - as a metric on sample space, 201, 278
 - generalized, 278

- Newton 张量, [200](#), [201–203](#), [275](#)
- Newton 方法, [202](#), [202](#), [203](#), [204](#), [276](#), [303](#)
- Newton's method
 - as a second-order method, [202](#)
- NLO 度量, *see* 度量
- non-Abelian gauge theory, *see also* Banks-Zaks fixed point
- non-Gaussian distribution, [25](#), *see also* nearly-Gaussian distribution, [314](#)
- non-informative prior, *see* prior
- non-parametric model, [132](#), *see also* Gaussian process, [314](#)
- nonlinear model, [230](#), [251](#)
 - cubic model, [252](#), [262](#)
 - quadratic model, [230](#), [252](#), [255](#), [258](#), [261](#), [262](#)
 - with wiring, [262](#)
- normal distribution, *see* Gaussian distribution
- normalization factor, *see also* partition function
- NTK, *see* neural tangent kernel
- objective function, *see also* loss
- observable, [9](#), [11](#), [17](#), [124](#), [150](#), [155](#), [193](#), [317](#), [319](#), [345](#)
- ODE limit, *see* gradient descent
- one-hot encoding, [134](#)
- one-parameter families, [218](#), [340](#)
- optimal aspect ratio, [303](#), [343](#), [345](#)
- optimization, *see* gradient descent, *see* training, *see also* direct optimization, *see also* Newton's method
- output matrix
 - $\gamma^{[a]}$ basis, *see* $\gamma^{[a]}$ basis
- overfitting, [132](#), *see also* generalization, [155](#), [309](#)
 - by fine tuning the parameters, [256](#)
- overly deep, [265](#), [316](#), [334](#), [335](#), [337](#)
- overparameterization, [132](#), [224–226](#), [309](#), [312](#), [313](#), [315](#)
 - in quadratic models, [254](#)
- Papert, Seymour, [87](#), [179](#)
- parallel susceptibility, [181](#), [182](#), [184](#), [187](#)
- parameter space, *see also* microscopic perspective, [264](#)
- parity symmetry, [20](#)
- partition function, *see also* normalization factor
 - quadratic action, [22](#)
 - with source, [12](#), *see also* generating function
- perpendicular susceptibility, [180–182](#), [184](#), [187](#)
- perturbation theory, [9](#)
- perturbative cutoff, *see* cutoff
- physics, [256](#), [317](#)
- piece of cake, *see also* free dynamics
- point estimate, *see also* mode
- Polchinski, Joseph, [9](#)
- positive semidefinite matrix
 - positive definite matrix, [13](#)
- posterior, [126–128](#), [133](#), [137](#), [139](#), [141](#), [146](#), [150](#), [208](#)
 - generalized posterior distribution, [195](#), *see also* gradient-based learning, [207](#), [208](#), [210](#), [212](#), [324](#)
 - infinite-width distribution, [139](#)
 - posterior covariance, [138](#), [139](#), [144](#), [145](#), [207](#)
 - finite width, [144](#)
 - posterior mean, [139](#), [144–146](#), [206](#), [304](#)
 - finite width, [144](#)
- practical practitioners, [160](#), [188](#)
- pretraining, [316](#), [333](#)
- prior, [125](#), [126](#), [129](#), [132–134](#), [144](#), [150](#), [151](#), [317](#), [323](#)
 - non-information prior, [318](#), *see also* Laplace's principle of indifference
- probabilistic model, [125](#), [131](#), [132](#)
- probability (branch of mathematics), [9](#), *see*

- also* Bayesian probability, *see also* frequentist probability, 26, 123
- probability distribution, 10
 - as a density, 321
- programming note, 137
- PyTorch, 345
- QED, 36
- quadratic model, *see* nonlinear model
- quadratic regression, *see also* quadratic model
 - nearly-linear, 253
- quantum mechanics, 150, 156
- Rabi, Isidor Isaac, 265
- RAID, 319, *see also* Redundant Array of Inexpensive Disks
- recurrent neural network, 191, 193
- redundancy (information theory), 317, 323, 334
- Redundant Array of Inexpensive Disks, *see also* RAID
- regression
 - linear, *see* linear regression
 - nearly-linear, *see* quadratic regression
 - polynomial, *see* polynomial regression
- regularization
 - early stopping, 205
 - for linear models, 224
 - interpretation of representation learning, 255
 - label smoothing, 205
- relative entropy, *see* Kullback–Leibler divergence
- relevant (RG flow), 179, 183, 190, 246, 329, 340
- ReLU, *see* 激活函数
- renormalization group flow, 276, 309, 333
- representation, 146, 157
- representation group flow, 140, 151, 156, 179, 229, 267, 276, 317, 329
 - of the ddNTKs, 267
 - of the dNTK, 233
 - of the NTK, 156
- representation learning, 148, 314
 - as the evolution of feature functions, 227
 - for deep linear networks, 228
 - for quadratic models, 252, 255
 - manifested at finite width, 277
 - meta representation learning, 286
 - minimal model, 230, 251, 252, 260, 262, 263
 - non-minimal model, 252
 - vs. fluctuations, 302
 - vs. kernel learning, 228
- residual block, 336, 343
- residual connection, 335, 337, 337, 338–340, 343
 - other names, 337
- residual hyperparameters, 343, 344
 - optimal, 343
- residual network, 263, 302, 317, 334, 335, 337, 338, 340
 - general, 344
- ResNet, 34, 337, 344
- RG 流, *see* 表征群流, *see* 重整化群流
- RG 流与 RG 流, 82, 99
- RNN, *see* 循环神经网络
- Rosenblatt, Frank, 29
- Rumelhart, David Everett, 179
- running coupling, 179, 328
 - quadratic, 328
 - quartic, 328
 - sextic, 330
- saddle-point approximation, 128, *see also* point estimate
- sample indices, 154
- sample space, ii
- saturation (of an activation), 192, 193
- scaling hypothesis, 309
- scaling law, 183, 190, 246, 302, 309

- Schrödinger's cat, [124](#)
- Schwinger–Dyson 方程, [68](#)
- Schwinger–Dyson equations, [147](#), [260](#), [279](#)
- second-order method (optimization), [201](#),
see also Newton's method, [202](#)
- second-order update, *see also* Newton tensor
 - generalized, [277](#), [278](#)
- self-averaging, [178](#), [196](#), [227](#)
- self-interaction, *see* interactions
- SGD, *see* stochastic gradient descent
- Shannon entropy, *see* entropy
- Shannon, Claude, [316](#)
- Shenker, Stephen, [56](#)
- shortcuts, *see* residual connection
- sigmoid, *see* 激活函数
- simple harmonic oscillator, [ii](#), *see also* Sho
- sin, *see* 激活函数
- six-point vertex, *see also* data-dependent coupling
- skip connection, *see* residual connection
- slay the beast (NTK variance), [174](#)
- small step, [196](#), *see also* giant leap
- softmax distribution, [126](#), *see also* logistic function, [127](#), [197](#), [205](#), [206](#)
- softplus, *see* 激活函数
- source term, *see also* generating function, [15](#)
- sparsity, principle of, [132](#), [310](#), [315](#)
 - near-sparsity at finite width, [311](#), [312](#), [314](#), [315](#)
- spoiler alert, [149](#), [183](#)
- statement, *see* Bayesian probability
- statistical dependence, [27](#), *see also* interactions, *see also* nearly-Gaussian distribution, [318](#), [319](#)
- statistical independence, [25](#), [26](#), [27](#), [140](#), [161](#), [162](#), [318](#), [319](#), [323](#)
 - absence of interactions and connection to Gaussian distribution, [25](#)
- statistical physics, [309](#), [317](#), [318](#), [326](#)
- statistics (branch of mathematics), [128](#), *see also* machine learning, [143](#), [309](#)
- statistics (of a random variable), [17](#), *see also* probability distribution
 - Bayesian interpretation, [123](#)
- stochastic gradient descent, [129](#), [204](#)
- str, *see* type (data)
- supervised learning, [154](#), [333](#)
 - with linear models, *see* linear regression
 - with quadratic models, *see* quadratic regression
- surprisal (information theory), [318](#), [320](#), [325](#)
- SWISH, *see* 激活函数
- synergy (information theory), [323](#)
- T-shirt equation, [297](#)
- tanh, *see* 激活函数
- Taylor 级数, [4](#), [29](#)
- tensor, [13](#), [23](#)
 - learning-rate tensor, *see* learning rate
 - Newton tensor, *see* Newton tensor
- tensor decomposition
 - ddNTKs $R/S/T/U$, [268](#), [299](#)
 - dNTK-preactivation P/Q , [237](#), [242](#), [299](#)
 - giving data-dependent couplings, [312](#)
 - metric mean and fluctuation, [147](#)
 - NTK mean and fluctuation, [162](#), [169](#), [242](#), [243](#), [275](#)
 - NTK variance A/B , [163](#), [174](#), [299](#)
 - NTK-preactivation D/F , [164](#), [171](#)
- tensorial gradient descent, *see* gradient descent
- test loss, *see* loss
- traditionality, *see also* exploding and vanishing gradient problem
- trained kernel, *see* nearly-kernel methods
- trained NTK, *see* neural tangent kernel
- training, [150](#), [153](#), [199](#)
- training dynamics

- controlled by the NTK, 150
- finite width, 273–296
- inductive bias, 265
- infinite width, 196–202
- training hyperparameters, 153
 - independent from the optimization algorithm, 282
- training loss, *see* loss
- training set, 206
- Transformer, 309, 344, 345
- transformer, 33, 34, 125, 131, 133
- translational invariance, 133
- trivial factor, *see also* exploding and vanishing gradient problem
- Turing, Alan, 42
- type (data)
 - floating-point precision, 322
 - integer, 27
 - string, 27
- type safety, *see also* dimensional analysis
- typicality, 156
 - principle of, 130, 302
- underparameterization, 224, 254
- universality
 - of the fully-trained network solution, 274, 296, 303
- universality class
 - $K^* = 0$, 179, 183, 184, 187–190, 192, 193, 213, 214, 216, 217, 246, 248, 270, 332, 340, 342
 - scale-invariant, 179, 183–188, 192, 193, 213, 216, 246, 247, 264, 271, 273, 332, 340, 342
- unsupervised learning, 316, 325
 - as pretraining, 333
- variance, *see also* cumulant
- variational ansatz, 327
- variational principle, *see also* maximum entropy, principle
- vectorial indices, 251
- von Neumann, John, 1, 30
- website, *see* deeplearningtheory.com
- Wick contraction, 145, 169, 174
- Wick 定理, 9, 12, 13, 17, 22–24, 49, 51, 52
- Wick 收缩, 17
- Wick 缩并, 44, 45, 47, 48, 51, 52, 58, 88
- Williams, Ronald J., 179
- wiring, *see also* Hebbian learning
 - in Bayesian inference, *see* Bayesian inference
 - in gradient-based learning, *see* gradient descent
 - in nearly-kernel methods, *see* nearly-kernel methods
- 三元信息, 322, 324, 334
- 中心极限定理, 38
- 中点核, *see* 核
- 中点输入, 92, 94, 97, 116
- 临界初始化超参数, *see* 初始化超参数
- 临界性, 42, 45, 46, 46, 50, 51, 54, 55, 88–91, 97–104, 107, 109–112, 114–117, 119, 133–135, 137, 143, 179, 184, 185, 187, 191–193, 211, 215, 217, 264, 267, 270, 314, 324, 344, 345
 - 半临界性, 99, 104, 112
 - 原理, 88, 123
- 临界指数, 105, 111, 113–115, 120, 183, 185, 188, 189, 194, 246, 248, 250, 269
- 临界温度, 46
- 临界现象, 46
- 二次回归, 253, 253, 282
- 二阶更新, 201, 201, 277
- 互信息, 316, 317, 320, 320, 322–324
- 交叉熵, 320
- 人工智能, 1, 29, 30, 30, 42
- 人工神经元, 29, 30, 143
- 人工神经网络, *see* 神经网络
- 人类感知, 31
- 作用量, 9, 21, 22, 27, 56, 317
 - 二次, 52, 59

- 有效, *see* 有效作用量
- 信息, **318**, **319**
- 信息时代, **2**, **3**, **316**
- 信息论, **8**, *see also* 统计力学, **113**, **316**, **317**, **318**
- 假设 (贝叶斯推断), **123**
- 偏差-方差分解, **210**
- 偏差-方差权衡, **210**, **212**, **301**, **324**
- 偏置, *see also* 模型参数, **151**
- 元假设, **131**
- 先验, **124**, **125**, **126**, **128–132**, **143**
- 全连接网络, **31**, *see also* 多层感知机
- 八重道, **ii**
- 六点顶角, **313**
- 典型性, **50**, **56**, **109**
- 内插, **218**
- 函数逼近, *see also* 机器学习, **4**, **30**, **30**, **31**, **37**, **38**, **42**, **125**, **127**, **128**, **133**, **150**, **151**, **154**, **155**
- 分子, **2**
- 分类, **205**, **269**, **324**
- 分部积分, **97**, **168**
- 初始化分布, **3**, **38**, **43**, **97**, **109**, **123**, **125**, **129**, **137**, **143**, **150**, **151**, **158**, **160**, **310**
- 初始化超参数, **38**, **42**, **46**, **51**, **87**, **88**, **90**, **98–100**, **117**, **122**, **125**, **135**, **179**, **181**, **185–187**, **193**, **204**, **207**, **212**, **215**, **217**, **229**, **338**, **345**
- 临界, **46**, **88**, **90**, **91**, **98**, **100**, **101**, **104**, **108**, **109**, **112**
 - 用于 $K^* = 0$ 普适性, **104**
 - 尺度不变普适性, **98**, **101**
 - 有限宽度下, **114**, **115**
- 初始化 (读者的), **1**
- 前向传播, **160**
- 前馈网络, **32**
- 半临界性, *see* 临界性
- 半正定矩阵, **153**
- 半群, **84**, *see also* RG 流
- 协方差, **19**
- 单位矩阵, **13**
- 卷积神经网络, **33**, **43**
 - 带残差连接, *see* ResNet
- 原子, **2**, **46**
- 原理, **1**
 - InfoMax, *see* InfoMax 原理
 - 临界性, *see* 临界性
 - 典型性, *see* 典型性
 - 变分, *see* 变分原理
 - 学习率等价, *see* 等价原理
 - 无差别, *see* Laplace 无差别原理
 - 最大熵, *see* 最大熵原理
 - 稀疏性与近稀疏性, *see* 稀疏性原理
- 参数, *see* 模型参数
- 参数空间, **153**, **200**, **201**, **313**
- 双阶乘, **12**
- 反向传播, **34**, **149**, **160**
- 变分原理, **316**, **325**
- 变分拟设, **325**
- 古典老派计算, **165**
- 可观测量, **2**, **154**, **155**
- 后验, **122**, **124**, **126**, **130**, **131**, **133**, **143**, **207**
- 向量指标, **151**, **155**
- 品牌认知, **297**
- 哈密顿量, **150**, **154**
- 四点顶点, *see also* 依赖数据的耦合, **64**, **80**, **109**, **111**, **112**, **114**, **115**, **143**
- 四点顶角, **130**, **146**, **163**, **165**, **173**, **178**, **179**, **183**, **185**, **188**
- 回归, **205**, **269**
- 固定点
 - 平凡, **46**, **89**, **90**, **97**, **98**, **108**
 - 非平凡, *see also* 临界性, **46**, **90**, **99**, **101**, **103**, **104**, **106**, **112**
 - 半稳定, **107**, *see also* GELU, *see also* SWISH, **108**
- 图形处理器, **29**
- 均值, **19**
- 均匀分布, **38**
- 垂直感受率, **339**

- 垂直敏感度, 214
- 垂直易感率, 97, 99, 135, 136, 193, 246
- 基本运算, 29
- 外推, 218
- 多层感知机, 29, 31, 32, 60, 63
 - 又称全连接网络, 31
- 多项式回归, 256
- 大型科技公司, 49
- 大脑, 1, 30, 33, 42
- 奥卡姆剃刀, 123, *see also* 稀疏性原理, 132, 132, 133, 135, 255, 309, 310, 318
- 学习率, 153, 160, 190
- 学习算法, 4, *see also* Bayes 推断, *see also* 梯度下降, 30, 42, 122, 128, 129, 133, 153, 206, 258, 303, 312
- 宇称对称性, 19, 26
- 宏观视角, 2, *see also* 样本空间, 132, 309, 314, 315
- 宽度, 6, 31
- 对偶性, 7, 191
- 对角化, 14, 93, 117
- 寻求刺激者的冒险, 245, 301
- 小步, 199
- 尺度不变性, 36, 37, 90, 98, 99, 108
- 层, 3, 31
- 层内相关, 165
- 层归一化, 345
- 层指标, 142, 143, 172, 220, 251, 323
- 层间相关, 149, 166, 168, 198
- 工业时代, 2
- 工程工作, 344
- 左矢-右矢记号, 24
- 巨大飞跃, 275
- 差分方程, 283, 284, 286-288
- 平凡因子, 191
- 平凡固定点, *see* 固定点
- 平板电脑, 181
- 平移不变性, 33, 43
- 平行感受率, 339
- 平行敏感度, 212
- 平行易感率, 96, 99, 135, 136, 188, 192, 246
- 并非真正深度, 8, *see also* 无限宽极限
- 广义相对论, 14, 168
- 度量, *see also* 依赖数据的耦合, *see also* 核, 58
 - 平均, 64
 - 无限宽极限, 80
 - 次领先阶修正, 80, 82
 - 次领头阶修正, 109-111, 113-115
 - 第 ℓ 层, 72
 - 第一层, 58
 - 第二层, 63
 - 逆, 59
 - 随机, 63
- 廉价磁盘冗余阵列, 319
- 张量, 4, 59, 153, 200
- 张量分解
 - $\gamma^{[a]}$ 基底, *see* $\gamma^{[a]}$ 基底
 - 六点相关子, 52
 - 四点相关子, 48
 - 度量均值与涨落, 68
- 归一化因子, 10, 13, 21, 78, 93, 131
- 归纳偏置, 51, 89, 109, 122, 123, 132, 133, 141-143, 192, 315, 343
 - 模型架构的, 33
- 彩票假设, 329, 334
- 微扰理论, 7, 23, 25, 26, 94, 284, 312
- 微扰论, 253
- 微观视角, 2, *see also* 参数空间, 304, 309, 314
- 思想推断, 133
- 思想模型, 315
- 恒等算子, 283
- 惰性训练, 279
- 感知机, *see* 感知机架构
- perceptron, *see* 激活函数
- 感知机架构, 29, 31
- 截断
 - 有效理论, 114, 115
- 截断正态分布, 38
- 截断, 有效理论, 88

- 批次, 203
- 批量, 153
- 折点, 36, *see also* leaky ReLU, *see also* ReLU
- 损失, 127, 128, 150, 151, 152–154, 192
- 数据依赖性, 105, *see also* 数据依赖耦合, *see also* 连通关联函数, 113
- 数据依赖耦合, 73, 78, 82
- 数据分布, 151, 151, 152
- 数据集, *see* 输入数据
- 方差, 10, 13
- 无关的 (RG 流), 86
- 无监督学习, 84, 303, 333, 340, 343
- 无限宽度极限, 180, 192, 196
- 无限宽极限, *see also* 并非真正深度, 6, 50, 54, 56, 75, 109, 132, 140, 141, 161, 164, 174, 178, 302, 314, 324, 340
 - 深度线性网络, 49
- 时空, 122
- 易如反掌, 283
- 易感率
 - 垂直, *see* 垂直易感率
 - 平行, *see* 平行易感率
- 普适性, 84, 88, 99, 179, 309
- 普适类, 99
 - $K^* = 0$, 101, 103, 104, 106, 112–114, 121
 - 半稳定, 108
 - 尺度不变, 100, 101, 104, 109–117, 119
 - 由标度律跨越, 113
- 晶体管, 2
- 最优深宽比, 8, *see also* 有效深度, 316, 325, 333, 337, 340, 343, 345
- 最优纵横比, 265
- 最优脑损伤, 329, 334
- 最大似然估计, 128, 129
- 最大后验, 128
- 最小模型, 8
 - 深度学习的, 33
- 有向无环图, 32
- 有效作用量, 99
 - 与 RG 流的联系, 85
 - 作为有效理论, 84
 - 物理学中, 85
- 有效深度, *see also* 最优深宽比
- 有效深度的, 8
- 有效理论, 2, 34, 75, 84, 85, 99, 100, 109, 114, 115, 128, 130, 132, 159, 160, 190, 259, 296, 309, 314, 321
- 期望值, 17
- 机器学习, *see also* 统计学 (数学分支), 30, 34, 123, 132, 160, 206, 222, 251, 309, 315
- 权重, *see also* 模型参数, 151
- 权重绑定, 33, *see also* 卷积神经网络
- 架构, 6, 31, 33, 87, 154
- 架构超参数, 31, 42, 51, 125
- 标度假设, 246, 269, 310, 315
- 标度律, 113, 250
- 标度拟设, 112, 113, 115, 120
- 标签, 151, 192, 205
- 样本指标, 30, 39, 47, 51, 59, 78, 92, 109, 110, 127, 129, 151, 155, 161, 163, 164, 171, 180, 181, 201
- 样本空间, 200, 201, 275, 278, 313
- 核, *see also* 度量, 80, 83, 88, 109, 179, 180, 183, 192, 193
 - δ 展开, *see* δ 展开
 - $\gamma^{[a]}$ 基底, *see* $\gamma^{[a]}$ 基底
 - 中点, 92, 93–95, 97, 101, 103–105, 107, 108, 116
 - 度量的无限宽极限, 80
- 核矩阵
 - 对角, 116, 119
 - 极角参数化, 116
 - 线性化递归, 89
- 核方法, 225, 251, 256, 259
- 核爆炸与消失问题, 46, 89, 90, 98, 135, 191, 192, 194
- 梯度, 5
- 梯度下降, 42, 129, 150–152, 154–157, 179, 192, 203, 258, 304, 312

- 梯度爆炸与消失问题, 46, 97, 179, 191, 191, 192, 193, 212, 335, 338, 340, 344
- 梯度裁剪, 193
- 检查点, 313
- 概率分布, 9, 10, 13, 15, 17, 18, 19, 21, 22, 38, 317
- 概率模型, 123, 126, 151
- 模型参数, 3, *see also* 偏置, *see also* 权重, 30, 31, 39, 41, 131, 150–153, 309, 312, 313
- 与可观测量的联系, 2
- 模型复杂度, 132, 255, 309, 310, 312–315
- 欠拟合, 209, 210
- 次领先修正, *see also* $1/n$ 展开, 80, 81, 82, 180
- 次领头修正, 109, 113–115
- 正交矩阵, 13, 26
- 正则化, 128, 129, 205, 207, 255
- 正则化超参数, 207
- 步演化算子, 284, 285, 287, 290
- 残差函数, 335
- 残差块, 335, 338, 344
- 残差网络, 33, 336, 344
- 残差超参数, 338
- 残差连接, 8, 33
- 求逆张量, 287, 288
- 没有免费午餐定理, 315
- 泛函, 317, 320
- 泛化, 152, 153, 155, 209, 324
- 泛化误差, 209, 211, 214, 218
- 注意, 33
- 注意力, 33, *see also* transformer
- 测试集, 152, 196, 202, 206, 209, 210, 314
- 涌现尺度, 42, 49, 88, 109, 183
- 涨落, 42, 50, 51, 88, 109, 123, 302, 314, 340
- 深度线性网络, 50
- 深度, 6, 31
- 深度学习, 1, 8, 30, 34, 87, 122, 125, 131, 141, 153, 160, 179, 189, 191, 309, 315
- 历史, 29
- 深度而尚未学习, 122
- 深度学习有效理论, 33, 42, 51, 56, 57, 130, 133, 151
- 深度学习理论原理, 33, 263
- 深度学习的有效理论, 88
- 深度线性网络, 42, *see also* linear, 42, 43, 45–47, 51, 88–90, 99, 109, 111, 115
- 深线性网络, 120, 218, 222, 228
- 混合方法, 345
- 混沌, 51, *see also* 过深, 315
- 温度, 46
- 源项, 12, 166
- 激活, 31
- 激活函数, 31, 34
- quadratic, 88
- monomial, 102
- perceptron, 31
- 激活的饱和, 34, 36
- 炒作, 309
- 点估计, 128
- 热力学, 2, 317
- 熵, 316, 317, 318–320, 322, 323
- 牛顿第二定律, 150
- 物理, 56, 57, 60, 99, 143, 145
- 物理学, 2, 2, 7, 84, 128, 253, 271, 317
- 物质, 2
- 特征, 33, *see also* 表征, 51, 125, 155, 157
- 特征函数, 251
- 随机, 7, *see also* 随机特征模型
- 特征空间, 224, 257
- 狄拉克 delta 函数, 271
- 独热编码, 205
- 瓶颈, 43
- 生命、宇宙以及一切, 122
- 生成函数, 12, 15, 16, 18, 166, 168, 198, 238
- 生物神经元, 29, 30, 123
- 生物神经网络, 1, *see also* 大脑, 195
- 电子书, 181
- 监督学习, 151, 152

- 目标函数, 151
- 直接优化, 253, 258, 282
- 相互作用, 7, 27, 27, 49, 82, 88, 109, 141, 161, 165, 314, 320
- 相互作用 NTK, 286, 293
- 相互作用理论, 7, 25
- 相关子
 - $2m$ 点, 53
 - M 点, 43
 - 二点, 44, 45
 - 六点, 52
 - 四点, 47, 49
 - 高阶, 46, 51, 54
- 相关的 (RG 流), 86, 109, 113, 115
- 相变, 46
- 真正, 277
- 知识蒸馏, 205
- 硬盘, 317
- 磁场, 46
- 磁性, 46
- 神经元, 1, 3, 30, 32
- 神经元指标, 39, 45, 48, 52, 59, 80, 109, 143, 157, 158, 161, 162, 169, 174, 197, 251
- 神经关联, 123, *see also* Hebb 学习, 141–143, 343
- 神经切向核, 110
- 神经正切核, 150, 154, 156, 180, 284
- 神经正切核的微分, 229
- 神经科学, 29
- 神经网络, 1, 3, 29, 30, 33, 87
 - 历史, 29
- 积分掉, *see also* 边缘化, 63, 78
- 积分表示, 40, 60
- 稀疏性原理, 6, 7
- 等价原理, 248, 249, 270, 282
- 等效原理, 193, 193, 194, 214–217
- 简谐振子, 42
- 算法依赖性, 258, 274, 285, 296, 298, 303, 312
- 算法无关性, 203, 204, 274
- 类型安全, 27, 285
- 粗粒化, 57, *see also* 表征群流, *see also* 重整化群流, 84
- 精细调节, 46
- 系综, *see also* 概率分布, 38, 97, 109, 115, 123, 130, 150
- 紫外 (RG 流), 85
- 红外 (RG 流), 85
- 线性变换, 43
- 线性回归, 223, 224, 251, 253
- 线性模型, 209, 222, 223, 251, 279, 304, 311
- 结果空间, 320, 321
- 结语, 309, 314
- 绝对确定, 124, 126, 133
- 绝对确定性, 205, 317
- 统计力学, *see* 统计物理学
- 统计物理, 46, 88
- 统计物理学, 2
- 统计独立性, 26, 49, 109, 164
- 编程, 30, 37
- 缩放律, 183
- 缩放拟设, 190
- 置换对称性, 37, 38, 97, 340
- 群表示论, 84
- 耦合
 - 二次, 78, 80, 82
 - 四次, 49, 55, 78, 82
 - 数据依赖, *see* 数据依赖耦合
 - 跑动, *see* 跑动耦合
- 自平均, 40, *see also* Dirac delta 函数, 64
- 自旋, 46, *see also* 比特 (熵的单位), 92
- 自然对数, 317
- 自然性, 256
- 自然语言处理, 33, 151
- 自由度, 84, 319, 323
- 自由能, 325
- 艰巨的坐标变换, 117
- 蒸汽机, 2
- 蓝图, 344
- 行列式, 14

- 表征, 57, *see also* 特征, 109, 141
- 表征学习, 1, 7, 50, 133, 140, 141, 143, 146, 149, 206, 222, 227, 251, 263, 289, 302
- 表征群流, 57, 86, 99, 104, 105, 107, 109, 113, 115, 222, 227, 263, 309, 340
 - 名称, 84
 - 预激活量, 56
- 表示, 125
- 表达能力, 31
- 计算机视觉, 33, 43, 133, 151, 344
- 认知科学, 29
- 训练, *see also* 梯度下降, *see also* 模型拟合, 4, 30, 37, 129, 151–153, 180, 191–193
- 训练数据, *see* 训练集
- 训练结束, 207, 259
- 训练超参数, 129, 158, 158, 179, 180, 193, 204, 207–209, 213–215, 217, 230, 338
- 训练集, 4, 152, 152, 153, 155, 196, 200, 202, 209, 309, 314
- 设计, 304
- 语言模型, 33
- 误差函数, 37
- 误差反向传播, 160, 191
- 误差因子, 154, 155, 157, 159, 191, 197
- 诱导分布, 39, 41
- 说明手册, 301
- 贝叶斯推断, 122, 123, 124, 125, 127–130, 132, 133, 150, 197, 202, 204, 207, 208
 - 模型拟合, 122
 - 模型比较, 122
 - 证据, 122
 - 预测, 122
- 贝叶斯概率, 123, 123
 - 乘法规则, 123
 - 求和规则, 124
 - 贝叶斯法则, 124
- 负对数似然, 127, 128
- 超参数
 - 初始化, *see* 初始化超参数
 - 架构, *see* 架构超参数
 - 残差, *see* 残差超参数
 - 训练, *see* 训练超参数
- 跑动耦合, 49, 51, 55, 78–80, 82, 84
 - 二次, 78, 79
- 转移矩阵, 71
- 轮次, 153
- 输入数据, *see also* 测试集, *see also* 训练集, *see also* 验证集, 30, 33, 39, 44, 76, 77, 109
- 输出分布, 39, 41, 50, 54, 126, 150
- 输出矩阵, 136
- 边缘化, *see also* 积分掉, 63, 80, 162
- 边缘化规则, 76, 77, 78
- 边缘的 (RG 流), 86, 115
- 过拟合, 209, 210
- 过深, *see also* 混沌, *see also* 退化问题
- 过深的, 8
- 近核方法, 230, 251, 258, 259, 260, 297
- 近高斯分布, 8, 21, 22, 25, 27, 49, 55, 62, 65, 69, 162, 165, 300, 312, 313
 - 作用量, 69
- 连续极限, 284
- 连通相关子
 - 六点, 55
 - 四点, 42, 46, 49, 55
- 退化问题, 343
- 逆算法设计, 304
- 通道, 33, *see also* 卷积神经网络
- 配分函数, 12, 15, 21, 23, 59, 73
- 重整化群流, 99, 114
- 量子力学, 2, 42
- 量子电动力学, *see* QED
- 量纲分析, 112, 246, 269, 317
- 钟形曲线, 10, 11
- 铁, 46
- 铁磁性, 46
- 链式法则, 154, 157, 158, 191

链式法则因子, 157, 191
阻尼力, 289–291, 298
随机元特征模型, 262
随机梯度下降, 153, 199, 203
随机特征函数, *see* 特征函数
随机特征模型, 226, 262
隐藏层, 33
雅可比因子, 321
雅可比矩阵
 输入–输出, 110
集成, 343
零初始化, 37, *see also* 初始化分布, 340
非平凡固定点, *see* 固定点
非高斯分布, 26, 54
鞍点近似, 128
顺磁性, 46
预激活量, 30
预训练, 9
频率主义概率, 123
题词, 314
验证集, 209
高斯函数, 10, 13, 30
高斯分布, 6, 17, 26, 38, 43, 52, 54, 109,
 161, 236, 311, 312
 与 Dirac delta 函数的关系, 40
 作用量, 59
高斯期望, 62, 117, 119, 121, 168
高斯积分, 10
魔术, 40, 166
黑箱, 2

术语索引

中文术语	英文术语	页码
有效作用量	effective action	82
四点顶点	four-point vertex	83
特征	feature	84
表征	representation	84
表征群流	representation group flow	84
重整化群流	renormalization group flow	84
相关的	relevant	86
无关的	irrelevant	86
边缘的	marginal	86
平行易感率	parallel susceptibility	90
非平凡固定点	nontrivial fixed point	90
中点输入	midpoint input	92
中点核	midpoint kernel	92
垂直易感率	perpendicular susceptibility	96
临界指数	critical exponent	104
标度拟设	scaling ansatz	105
半稳定的	half-stable	108
半稳定普适类	half-stable universality class	108