

优化与机器学习中的统计物理方法

副本、空腔与消息传递技术导论

Statistical Physics Methods in Optimization and Machine Learning

Florent Krzakala　Lenka Zdeborová

2024-06-09 冻结讲义可见内容译稿

译本说明：本译稿限于本地冻结的 2024 版讲义可见内容。第 19 章在原稿中仅有标题和题辞，没有正文；本译稿不补写该章。两版讲义分别翻译，不拼合为一部完整课程。

本次机器审校修订仍待独立复验。下列审核署名为项目格式，不表示署名者本人已逐页实审，也不表示主控已验收。早期初译模型未确认。

讲义 2024-06-09 版 · 出版方未确认 · 2024
Model: gpt-6.1-sol（本轮；早期模型未确认）
审核：曹溪能
Updated: 2026-11-06

引言

> 我认为适宜在同一本书中详细说明某种方法的独特之处，通过这种方法，可以借助力学研究数学中的一些问题。这一过程对于定理本身的证明也同样有用；因为有些事情最初是通过一种力学方法向我显明的，尽管它们后来必须用几何学加以证明。然而，当然，当我们事先借助这种方法对问题有了一些了解时，提供证明比没有任何先验知识就去寻找证明更容易。我确信，它对数学将有不小的帮助；因为我认为，一旦这种方法建立起来，我的一些同时代人或后继者就能够借助它发现其他我尚未想到的定理。
>
> 《机械定理的方法》
> 阿基米德致埃拉托斯特尼的信，约公元前 220 年

本系列讲义将讨论概率模型，重点研究统计学、机器学习和约束优化中出现的问题，同时使用统计物理的工具与技术。重点将偏向理论而非实践，特此提醒！我们的目标是展示统计物理中的一些方法如何使我们能够对许多数学问题推导出精确答案。正如阿基米德所指出的，一旦给出这些答案，即使它们是通过启发式方法得到的，严格证明它们也是一项较为简单（但仍然并非平凡）的任务。过去几十年里，理论物理与应用数学的兴趣和方法日益趋同，统计物理和计算机科学中的许多理论与应用工作，都依赖于它们与自旋玻璃统计物理的联系。本课程旨在介绍进入这一快速发展领域所需的背景。

乍看之下，物理学与最小化和概率推断问题有任何联系或许令人惊讶。这种联系在于 Gibbs（或 Boltzmann）分布，它是统计力学中的基本对象。从统计学与优化的角度看，我们将关注两类问题：(a) 最小化一个代价函数；(b) 从一个分布中采样。在这两种情况下，统计物理方法，或者更准确地说 Boltzmann 测度，都很便利。

假设有一个关于 $\mathbf{x} \in \mathbb{R}^d$ 的“代价”函数 $E(\mathbf{x})$。在统计力学中，人们给 $\mathbf{x}$ 的每个可能取值关联一个依赖温度的“Boltzmann”概率测度，如下所示：

$$\mathbb{P}^{\text{Boltzmann}}(\mathbf{x}) = \frac{1}{Z_N(\beta)} e^{-\beta E(\mathbf{x})},$$

其中 $\beta = 1/T$ 称为逆温度，而

$$Z_N(\beta) = \int_{\mathbb{R}^d} d\mathbf{x}\, e^{-\beta E(\mathbf{x})}$$

称为配分函数或配分和。引入温度非常实用。例如，可以验证极限 $\beta \to \infty$ 能够让我们研究最小化问题，因为

$$\lim_{\beta \to \infty} -\partial_\beta \log Z(\beta) = \min_{\mathbf{x}} E(\mathbf{x}).$$

还可以通过计算 $\lim_{\beta\to\infty} Z(\beta)$ 得到极小点的数目。

这一形式体系对于采样问题同样有趣。统计推断、信息论、信号处理或机器学习中出现的一个典型问题如下：设 X 是我们希望推断、但无法直接获得的未知量。我们能够获得与 X 相关的量 Y（通常是 X 的一个带噪版本）。具体而言，假设 X 是零均值、单位方差的标量高斯变量，并且对于另一个标准高斯变量 Z 有 $Y = X + Z$。给定 Y，我们能够对 X 作出什么判断？换言

之，给定测量值 Y 时 X 的概率是什么？量 $\mathbb{P}_{X|Y}(x,y)$ 称为给定 Y 时 X 的后验分布。著名的 Bayes 公式指出

$$\mathbb{P}_{X|Y}(x,y)=\frac{\mathbb{P}_{Y|X}(x,y)P_X(x)}{P_Y(y)},$$

因此，后验 $\mathbb{P}_{X|Y}(x,y)$ 等于 X 的先验概率 $P_X(x)$ 与似然 $\mathbb{P}_{Y|X}(x,y)$ 的乘积，除以证据 $P_Y(y)$；后者只是归一化常数（就其不是我们关心的随机变量 X 的函数而言）。

当然，这可以直接改写为

$$\mathbb{P}_{X|Y}(x,y)=\frac{e^{\log[\mathbb{P}_{Y|X}(x,y)P_X(x)]}}{P_Y(y)},$$

因此，只要作如下对应，它就可以表示为 Boltzmann 测度：

$$\beta=1,\qquad Z=P_Y(y),\qquad E=-\log\big[\mathbb{P}_{Y|X}(x,y)P_X(x)\big].$$

因此，证据 P_Y 就是配分和。这一简单改写是统计力学语言在 Bayes 推断中流行的原因。实际上，机器学习领域术语表中的许多词直接借自物理学（例如“基于能量的模型”“自由能”“平均场”“Boltzmann 机”等）。

下文中，我们将关注所得估计的准确程度，例如在给定模型集合上计算均方误差。因此，我们不仅需要应用统计物理方法推导后验分布和配分和，还需要对许多模型或许多实现取平均，以确定典型行为。例如，我们希望获得熵等信息论量。计算配分和 Z 已经很困难，而众所周知，计算这类平均更加困难。

方便的是，统计物理中恰有一个分支专门研究这一任务：无序系统与自旋玻璃领域。自旋玻璃是一类磁体，其中每对粒子之间的相互作用强度是随机的。自 20 世纪 70 年代末 Sir Sam Edwards 和诺贝尔奖得主 Philip W. Anderson 的开创性工作以来，无序系统与自旋玻璃的统计物理已发展为用途广泛的理论，并拥有副本法、空腔法等强大的启发式工具。用统计物理方法研究计算机科学中的某些问题，这个想法本身并不新颖；例如，它启发了模拟退火的诞生。1986 年，Anderson 一方面以及 Parisi 和 Mézard 另一方面，利用这一联系研究优化问题。此后，许多人成功地用它研究了优化（随机可满足性与着色）、纠错编码、推断和机器学习中的各种问题。

在这些讲义中，我们希望用跨学科方法处理这些问题，利用数学物理和统计力学的工具，也利用信息论与优化的工具。我们的建模策略和分析源自凝聚态物理模型中相变的研究，但多数目标与应用属于机器学习、计算机科学和统计数据处理领域。

记号

我们采用概率论记号：随机变量用大写字母表示，其特定取值用小写字母表示。例如，我们用 $\mathbb{P}(X=x)$ 表示随机变量 X 取值 x 的概率。

$=:$ 定义一个新的量。

$\asymp$ 渐近相等，用于大偏差。

$\mathbb{P}(X=x)$ 随机变量 X 取值 x 的概率。

目录

第一部分：技术与方法 **8**

1 Curie 与 Weiss 的平均场铁磁体 **8**

1.1 严格求解 . . . 9
1.1.1 Curie–Weiss 模型中的相变 . . . 11
1.2 自由能 / 自由熵就是你所需要的一切 . . . 12
1.2.1 自由熵的导数 . . . 13
1.2.2 Legendre 变换 . . . 13
1.2.3 Gärtner–Ellis 定理 . . . 15
1.3 工具箱：Gibbs 自由熵与变分方法 . . . 16
1.4 工具箱：空腔法 . . . 17
1.5 工具箱：“场论式”计算 . . . 19
1.6 习题 . . . 22
附录 1.A：统计物理术语 . . . 27
附录 1.B：相变入门 . . . 28
附录 1.C：空腔法的严格版本 . . . 31

2 一个简单例子：随机场 Ising 模型 **34**

2.1 自平均与集中 . . . 35
2.2 副本方法 . . . 36
2.2.1 计算副本配分函数 . . . 36
2.2.2 副本对称假设 . . . 37
2.2.3 计算鞍点：平均场方程 . . . 38
2.3 使用插值技术的严格计算 . . . 39
2.3.1 一个简单问题 . . . 39
2.3.2 Guerra 插值 . . . 40
2.4 习题 . . . 42

3 第一个应用：随机矩阵的谱 **44**

3.1 Stieltjes 变换 . . . 44
3.2 副本方法 . . . 45
3.2.1 对副本取平均 . . . 46
3.2.2 副本对称假设 . . . 48
3.2.3 从 Stieltjes 变换到谱 . . . 48
3.3 空腔方法 . . . 49
3.4 习题 . . . 51

4 随机图上的随机场 Ising 模型 **51**

4.1 所有空腔论证的根源 . . . 52
4.2 树上的精确递推 . . . 52

4.2.1 两体模型在树上的信念传播 . . . 53
4.3 随机图上的空腔法 . . . 56
4.3.1 随机图 . . . 56
4.3.2 空腔方法 . . . 57
4.3.3 有环信念传播与空腔方法的关系 . . . 59
4.3.4 我们能证明它吗? . . . 59
4.3.5 何时预期这一方法有效? . . . 60
4.4 习题 . . . 60

5 稀疏图与局部树状图模型 62
5.1 图模型 . . . 63
5.1.1 图 . . . 63
5.1.2 因子图 . . . 63
5.1.3 因子图的一些性质与用途 . . . 67
5.2 信念传播与 Bethe 自由能 . . . 68
5.2.1 在树形图模型上推导信念传播 . . . 68
5.2.2 信念传播方程总结 . . . 72
5.2.3 如何使用信念传播? . . . 73
5.3 习题 . . . 75
附录 5.A：逐节点理解两体模型的 BP . . . 75

6 图着色的信念传播 80
6.1 导出所关心的量 . . . 80
6.2 将一般 BP 方程具体用于着色 . . . 81
6.3 着色的 Bethe 自由能 . . . 82
6.4 图着色的顺磁不动点 . . . 82
6.5 铁磁不动点 . . . 83
6.5.1 Ising 铁磁体，$q = 2$ . . . 85
6.5.2 Potts 铁磁体，$q \geq 3$ . . . 86
6.6 回到反铁磁（$\beta > 0$）情形 . . . 87
6.7 习题 . . . 91

第二部分：概率推断 93

7 去噪、估计与贝叶斯最优推断 93
7.1 Bayes–Laplace 逆问题 . . . 93
7.2 标量估计 . . . 94
7.2.1 后验分布 . . . 94
7.2.2 点估计推断：MAP、MMSE 等 . . . 96
7.2.3 回到自由熵 . . . 98
7.2.4 若干实用恒等式：Nishimori 与 Stein . . . 100

7.2.5 I-MMSE 定理 . . . 101
7.3 应用：稀疏向量去噪 . . . 102
7.4 习题 . . . 104
附录 7.A：似然比的更精细计算 . . . 105
附录 7.B：向量去噪的副本计算 . . . 107

8 低秩矩阵分解：尖峰模型 109
8.1 问题设定 . . . 109
8.2 从后验分布到配分和 . . . 110
8.3 副本方法 . . . 111
8.4 通过插值给出严格证明 . . . 114
8.5 习题 . . . 124

9 空腔法与近似消息传递 125
9.1 自洽方程 . . . 125
9.2 用空腔法处理秩一问题 . . . 127
9.3 AMP . . . 128
9.4 习题 . . . 130

10 随机块模型与社区发现 130
10.1 模型定义 . . . 130
10.2 贝叶斯推断与参数学习 . . . 132
10.2.1 已知参数的社区发现 . . . 132
10.2.2 学习参数 . . . 133
10.3 SBM 的信念传播 . . . 133
10.4 社区发现的相图 . . . 136
10.4.1 二阶相变 . . . 136
10.4.2 顺磁不动点的稳定性 . . . 138
10.4.3 一阶相变 . . . 139
10.4.4 非回溯矩阵与谱方法 . . . 140
10.5 习题 . . . 141

11 从稀疏图到稠密图的自旋玻璃博弈 141
11.1 自旋玻璃博弈 . . . 142
11.2 稀疏图 . . . 142
11.2.1 信念传播 . . . 142
11.2.2 群体动力学 . . . 143
11.2.3 相变 . . . 144
11.3 稠密图极限：TAP / AMP . . . 144
11.4 近似消息传递 . . . 145
11.4.1 状态演化 . . . 146

11.5 从自旋玻璃博弈到秩一分解 147

12 近似消息传递与状态演化 147

12.1 对理想迭代的一厢情愿分析 148
12.2 近似消息传递及其状态演化 148
12.2.1 对称 AMP 149
12.2.2 对线性观测取条件 149
12.2.3 AMP 的收敛性 152
12.2.4 第一个应用：TAP 方程 152
12.2.5 再看 Parisi 方程：近似调查传播 153
12.3 应用 153
12.3.1 Wigner 尖峰模型 153
12.3.2 贝叶斯去噪入门 155
12.3.3 Wishart 尖峰模型 156
12.4 从 AMP 到副本预测的证明：贝叶斯情形 157
12.5 从 AMP 到副本预测的证明：MAP 情形 159
12.6 矩形 AMP 与 GAMP 160
12.7 学习问题：LASSO 161
12.7.1 梯度下降 161
12.7.2 近端梯度下降 162
12.7.3 LASSO 及其他线性问题 163
12.7.4 再看 AMP 163
12.7.5 岭回归的例子 164
12.8 用 GAMP 推断 165

第三部分：随机约束满足问题 166

13 图着色 II：从植入得到的启示 166

13.1 SBM 与植入着色 166
13.2 植入与随机图着色的关系 167
13.2.1 BP 收敛与算法阈值 167
13.2.2 随机与植入系综的相接性及成簇 168
13.2.3 成簇阈值的上界 169
13.2.4 评论与文献 171

14 图着色 III：可着色阈值与簇的性质 171

14.1 成簇分析：一般讨论 171
14.2 分析 BP 不动点 172
14.3 计算可着色阈值 174
14.4 习题 177

15 副本对称性破缺：随机能量模型 177
15.1 严格解 . . . 178
15.2 副本法求解 . . . 180
15.2.1 一个有启发的界 . . . 181
15.2.2 副本对称解 . . . 181
15.2.3 副本对称性破缺解 . . . 182
15.2.4 凝聚相变与参与比 . . . 183
15.2.5 重叠的分布 . . . 184
15.3 副本势与复杂度的联系 . . . 184
15.4 习题 . . . 186

第四部分：统计学与机器学习 188

16 线性估计与压缩感知 188
16.1 问题陈述 . . . 188
16.2 松弛信念传播 . . . 188
16.3 状态演化 . . . 192
16.3.1 带帽变量 . . . 192
16.3.2 序参量 . . . 192
16.3.3 回到带帽变量 . . . 193
16.4 从 r-BP 到 G-AMP . . . 193
16.5 贝叶斯与凸优化的严格结果 . . . 195
16.5.1 贝叶斯最优 . . . 195
16.5.2 贝叶斯最优 . . . 196
16.6 应用：LASSO、稀疏估计与压缩感知 . . . 196
16.6.1 有限 Δ 的 AMP . . . 196
16.6.2 LASSO：无穷大 Δ . . . 196
16.7 习题 . . . 199

17 感知机 199
17.1 感知机 . . . 199

18 高维回归：精确渐近结果 204
18.1 线性模型的 AMP . . . 204
18.1.1 岭回归的例子 . . . 205
18.1.2 一般协变量的岭回归 . . . 206

第五部分：附录 208

19 一点概率论 208

参考文献 209

第一部分：技术与方法

1 Curie 与 Weiss 的平均场铁磁体

> 世界还非常年轻，许多事物尚无名称，人们要指出它们时只得用手指。每年三月，一个衣衫褴褛的吉卜赛人家庭便在村子附近搭起帐篷，在管乐和定音鼓的巨大喧闹声中展示新发明。他们最先带来了磁铁。
>
> 《百年孤独》
> Gabriel García Márquez，1967

Curie–Weiss 模型是一个简单的铁磁性模型。铁磁体所具有的基本现象是：在某个临界温度以下，即使不存在外磁场，也会自发出现磁化。Curie–Weiss 模型足够简单，以至于能够精确计算表征其宏观性质的全部热力学函数。然而，它又足够丰富，能够捕捉相变的基本现象学——即无序顺磁相（未磁化）与有序铁磁相（已磁化）之间的转变。由于它的简单性，以及至少部分预测的正确性，Curie–Weiss 模型在统计力学文献中占有重要地位。

在该模型中，磁矩由 N 个微观自旋变量 $S_i \in \{-1,+1\}$ 编码，其中 $i = 1,\dots,N$。每个磁矩 S_i 都与其他每个磁矩 S_j（$j \neq i$）相互作用。铁磁性可以通过磁矩沿同一方向集体排列来建模。因此，为促进铁磁相，我们对未对齐的自旋引入能量代价。在最简单的形式中，这一代价取两体相互作用 $-S_iS_j$ 的形式。与给定自旋构型 $\mathbf{S} \in \{-1,+1\}^N$ 关联的总代价函数，在物理学中也称为 Hamiltonian，给出为

$$\mathcal{H}_N^0(\mathbf{S}) = -\frac{1}{2N}\sum_{ij} S_iS_j.$$

加入一个恒定外场 $h \in \mathbb{R}$ 很方便：当 $h > 0$ 时它促使自旋取向 $S_i = +1$，当 $h < 0$ 时则促使自旋取向 $S_i = -1$。因此，我们使用如下 Hamiltonian：

$$\mathcal{H}_N(\mathbf{S}) = \mathcal{H}_N^0(\mathbf{S}) - h\sum_i S_i = -\frac{1}{2N}\sum_{ij} S_iS_j - h\sum_i S_i. \tag{1.1}$$

发现系统处于构型 $\mathbf{s} \in \{-1,+1\}^N$ 的概率由 Boltzmann 测度给出：[1]

$$\mathbb{P}_{N,\beta,h}(\mathbf{S} = \mathbf{s}) = \frac{e^{-\beta\mathcal{H}(\mathbf{s})}}{Z_N(\beta,h)},$$

其中 $\beta = T^{-1} \geq 0$ 是逆温度。注意，当 $\beta > 0$ 时，Boltzmann 测度对代价或能量较低的构型赋予更大权重。特别地，当 $\beta \to \infty$（等价地 $T = 0$）时，它集中于使 $\mathcal{H}$ 最小的构型附近。相反，当 $\beta = 0$（等价地 $T \to \infty$）时，它对每个构型赋予相等权重，从而得到均匀测度。Boltzmann 测度的归一化在统计物理中起着非常重要的作用，称为配分和或配分函数：

$$Z_N(\beta,h) = \sum_{\mathbf{S}\in\{-1,+1\}^N} e^{\frac{\beta}{2N}\sum_{ij} S_iS_j + \beta h\sum_i S_i}. \tag{1.2}$$

正如接下来将展示的，配分和与表征模型宏观性质的热力学函数紧密相关。

[1] 也称 Gibbs 测度或 Gibbs–Boltzmann 测度。

1.1 严格求解

如引言所述，在这里铁磁性由磁矩或自旋的排列来建模。因此，单自旋磁化强度是铁磁态的良好探针：

$$\bar{S} =: \frac{1}{N}\sum_{i=1}^{N} S_i.$$

注意，$\bar{S}$ 是自旋的经验平均，因此本身也是随机变量。有趣的是，Curie–Weiss 模型的 Hamiltonian 实际上只是磁化强度的函数：

$$\mathcal{H}(\bar{S}) = -N\left(\frac{1}{2}\bar{S}^2 + h\bar{S}\right),$$

由此可以明确看出它是一个广延量 $\mathcal{H}(\bar{S}) \propto N$。每次将单个自旋从 -1 翻转为 $+1$，单自旋磁化强度就增加 $2/N$。那么，单自旋磁化强度取集合 $\mathcal{S}_N = \{-1, -1+2/N, -1+4/N, \dots, 1\}$ 中某个特定值的概率是多少？由 Boltzmann 测度可得

$$\mathbb{P}(\bar{S} = m) = \frac{\Omega(m,N)}{Z_N(\beta,h)} e^{\beta N(\frac{1}{2}m^2 + hm)},$$

其中 $\Omega(m,N)$ 是满足磁化强度 $\bar{S} = m$ 的构型数。它可以显式计算，恰好由标准二项系数给出：

$$\Omega(m,N) = \frac{N!}{\left(\frac{N-Nm}{2}\right)!\left(\frac{N+Nm}{2}\right)!}.$$

上述表达式与通常的二项分布不同，因为 S_i 的取值属于 $\{-1,1\}$ 而非 $\{0,1\}$。乍看之下它不太

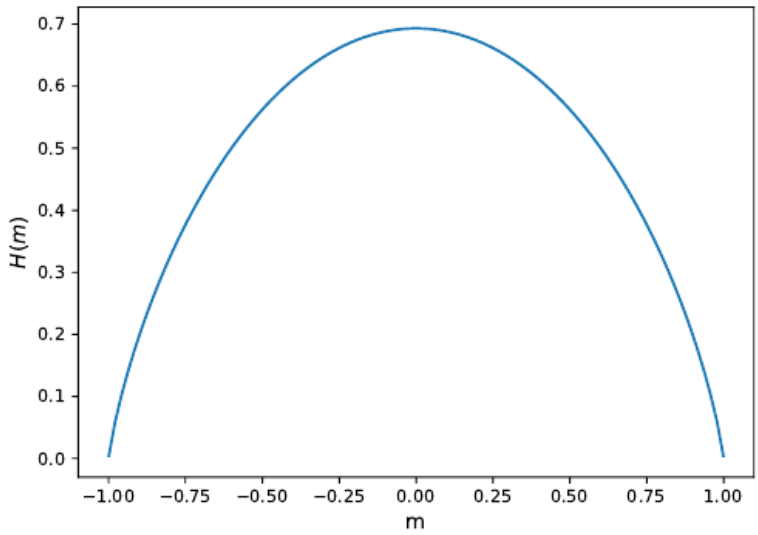


图 1.1: 式 (1.3) 定义的二元熵 $H(m)$ 随磁化强度 m 的变化。

友好，但通过进一步改进 Stirling 近似（见习题 1.1），可以证明

$$\frac{e^{NH(m)}}{N+1} \le \Omega(m,N) \le e^{NH(m)},$$

其中通常称为二元熵的 $H(m)$ 为[2]

$$H(m) = -\frac{1+m}{2}\log\left(\frac{1+m}{2}\right) - \frac{1-m}{2}\log\left(\frac{1-m}{2}\right). \tag{1.3}$$

于是得到第一个结果：

引理 1. 设 $\phi(m) = H(m) + \frac{1}{2}\beta m^2 + \beta h m$，则

$$\frac{1}{N+1}\frac{e^{N\phi(m)}}{Z_N(\beta,h)} \le \mathbb{P}(\bar{S}=m) \le \frac{e^{N\phi(m)}}{Z_N(\beta,h)}. \tag{1.4}$$

我们还可以计算并界定 $Z_N(\beta,h)$ 的值。事实上，对式 (1.4) 的右侧部分两边关于 m 求和，可得

$$1 \le \sum_m \frac{e^{N\phi(m)}}{Z_N(\beta,h)} \le (N+1)\frac{e^{N\phi(m^*)}}{Z_N(\beta,h)}, \tag{1.5}$$

其中 $m^* \in [-1,1]$ 定义为使 $\phi(m)$ 最大的值（注意 m^* 依赖于 β 和 h）。因此对两边取对数得到

$$\frac{\log Z_N(\beta,h)}{N} \le \phi(m^*) + \frac{\log(N+1)}{N}.$$

此外，式 (1.4) 的左侧部分告诉我们

$$\frac{1}{N+1}\frac{e^{N\phi(m)}}{Z_N(\beta,h)} \le \mathbb{P}(\bar{S}=m) \le 1,$$
$$-\frac{\log(N+1)}{N} + \phi(m) \le \frac{\log Z_N(\beta,h)}{N}.$$

这对所有离散值 $m \in \mathcal{S}_N$ 都成立，特别是对在此集合上使 $\phi(m)$ 最大的值 $m_{\max}$ 也成立。容易看出，在 $[-1,1]$ 上而非在 $\mathcal{S}_N$ 上求最大值并不会实质改变结果，因为 $\phi(m_{\max}) > \phi(m^*) - \log N/N^2$。[3] 因此，当 N 足够大时，最终得到

引理 2. 设 $\Phi_N(\beta,h) = \log Z_N(\beta,h)/N$，则

$$\phi(m^*) - \frac{\log(N(N+1))}{N} \le \Phi_N(\beta,h) \le \phi(m^*) + \frac{\log(N+1)}{N}. \tag{1.6}$$

我们称 $\log Z_N$ 为自由熵，而 $\Phi_N =: \frac{1}{N}\log Z_N$ 为自由熵密度。渐近地，它满足：

定理 1. 设 $\Phi_N(\beta,h) = \log Z_N(\beta,h)/N$，则

$$\Phi(\beta,h) =: \lim_{N\to\infty} \Phi_N(\beta,h) = \max_{m\in[-1,1]} \phi(m) = \phi(m^*). \tag{1.7}$$

$$\lim_{N\to\infty} \frac{\log \mathbb{P}(\bar{S}=m)}{N} = \phi(m) - \phi(m^*). \tag{1.8}$$

注意，这一结果相当惊人：我们把式 (1.2) 中看似不可能处理的 2^N 个状态之和，转化为对一维势函数 $\phi(m)$ 的简单最大化。特别地，式 (1.8) 表明，在热力学极限 $N\to\infty$ 下，势函数 $\phi(m)$ 完整地刻画了发现系统处于给定宏观状态 $\bar{S}=m$ 的概率。更重要的是，我们没有作任何近似就做到了这一点。每一步都是严格的！这当然要归功于 Curie–Weiss 模型的简单性。

[2]在信息论中，二元熵通常用 $\log_2$ 定义。这里我们坚持使用自然对数。

[3]对 m^* 与 $m_{\max}$ 之间应用中值定理，可得某个 $c \in [m^*, m_{\max}]$ 满足 $\phi(m^*) = \phi(m_{\max}) + \phi'(c)(m^* - m_{\max})$，并且 $|m^* - m_{\max}| \le 2/N$。由于差值对某个常数 K 为 K/N，最终会小于 $\log N/N$。

1.1.1 Curie–Weiss 模型中的相变

根据这个精确解，现在可以分析 Curie–Weiss 模型的现象学。极值条件 $\phi'(m) = 0$ 导出

$$\frac{1}{2}\log\left(\frac{1+m}{1-m}\right) = \beta(m+h),$$

使用 $\tanh^{-1}(x) = \frac{1}{2}\log[(1+x)/(1-x)]$ 可得所谓的 Curie–Weiss 平均场或鞍点方程：

$$m = \tanh\big(\beta(h+m)\big). \tag{1.9}$$

图 1.2 给出了固定外场 h 和不同逆温度 β 时平均场方程 (1.9) 的右侧。自洽方程的解 m^* 由

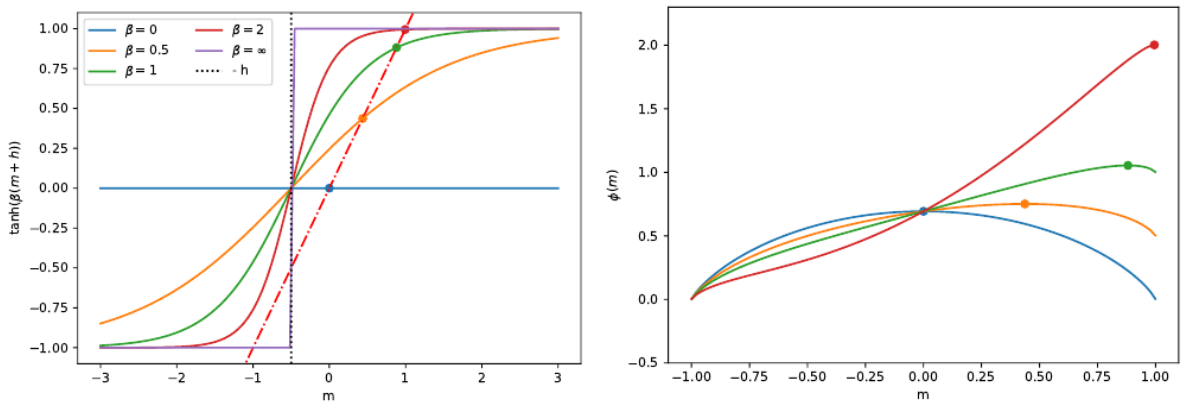


图 1.2: （左）固定 $h = 0.5$、对不同逆温度 β，式 (1.9) 的右侧随 m 的变化（实线）。式 (1.9) 的解（圆点）由 $f(m) = \tanh(\beta(h+m))$ 与直线 $f(m) = m$（红色虚线）的交点给出。（右）用势函数 $\phi(m)$ 表示的同一图景，其中式 (1.9) 的解对应于 $\phi(m)$ 的全局最大值。注意，当 $\beta \gg 1$ 时，会出现一个与 ϕ 的极小值对应的不稳定解。

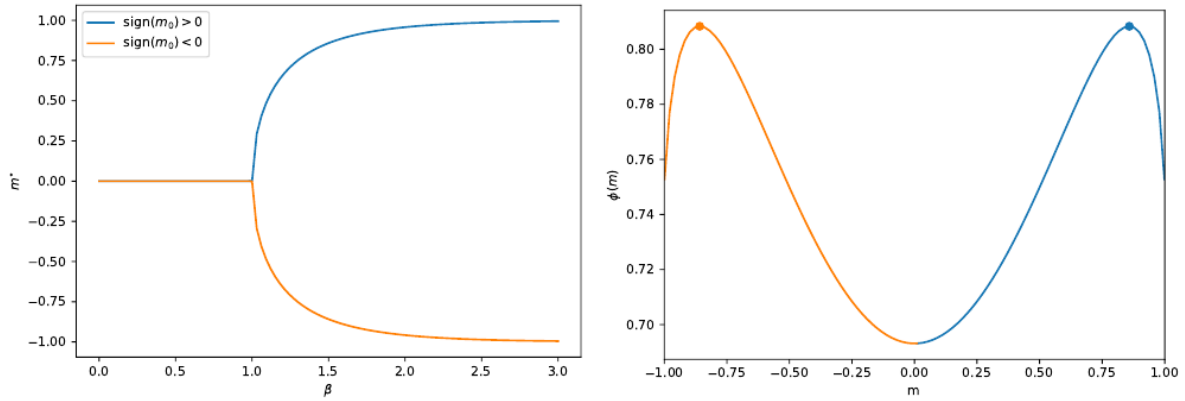


图 1.3: （左）平均场方程 $m = \tanh(\beta m)$ 在临界温度以上（$h = 0, \beta = 1.5$）的不动点 m^* 随逆温度 β 的变化。取决于初始值 m_0 的符号，我们会到达 $\phi(m)$ 的两个全局最大值之一（右图）。

$f(m) = \tanh(\beta(m+h))$ 与直线 $f(m) = m$ 的交点给出。根据参数值，最多可有三个解。

性质 $N^{-1}\log\mathbb{P}(\bar{S} = m) \to \phi(m) - \phi(m^*)$ 在数学中通常称为大偏差原理。它基本上表示，$\bar{S}$ 取任何不同于 m^* 的值的概率都指数地小，即是非常罕见的事件。简言之，我们可以把系统具有

给定 m 值的概率近似写为

$$\mathbb{P}(\bar{S}=m) \underset{N\to\infty}{\asymp} e^{N(\phi(m)-\phi(m^*))},$$

这里使用符号 $\underset{N\to\infty}{\asymp}$ 表示在 N 的渐近意义下成立的等式。如果最大值唯一，那么磁化强度以概率一等于 m^*。在概率论中，这种依概率收敛称为集中现象。对于物理学家而言，这意味着磁化强度等“宏观”量完全是确定性的，因为它们围绕均值的随机涨落可以忽略；这一测度集中是统计力学成功的根基。然而，在 Curie–Weiss 模型中，如果 $h=0$ 且 $\beta>1$，那么全局最大值不唯

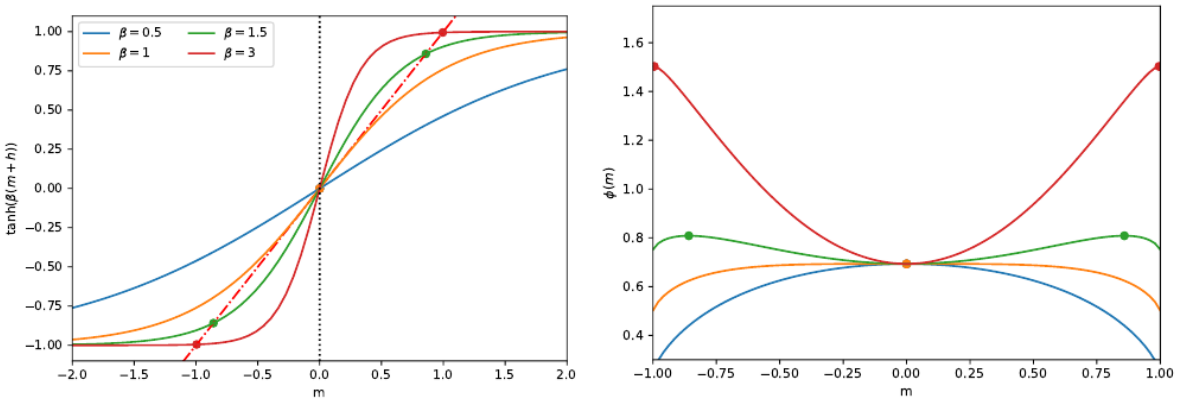


图 1.4: 与图 1.2 相同的情形，但外场为零 $h=0$。当 $\beta<1$ 时，势函数 $\phi(m)$ 只有一个最大值，对应无序相 $m^*=0$；当 $\beta>1$ 时，系统有两个有序铁磁相，对应于两个对称全局最大值 $\pm m^*$ 的出现。

一：在 $\pm m^*$ 处有两个简并的最大值。这意味着，如果从 Boltzmann 测度中抽取一个构型，那么该构型以概率 1/2 具有磁化强度 $\pm m^*$，见图 1.3 和图 1.4。这种情形在物理学中称为相共存，是自然界液体、固体和气体的一个基本性质。Curie–Weiss 模型中的相共存只在 $h=0$ 且 $\beta>1$ 时出现。事实上，如图 1.2 所示，$h\neq 0$ 时平均场方程可能有不止一个解，但只有一个全局最大值，对应单相，也称为单个 Gibbs 态。

1.2 自由能 / 自由熵就是你所需要的一切

对于更复杂的模型，我们不能指望像定理 1 中那样，通过直接计算得到有关量的统计分布。不过，我们应当预期会出现类似现象：热力学极限下宏观量的集中、Boltzmann 测度的大偏差原理、单相与相共存，以及当然还有相变。事实表明，几乎所有这些现象都可以通过计算渐近自由熵密度 $\Phi(\beta,h)$ 来理解。这就是为什么计算这一量是统计物理中最重要的单项分析任务。

首先说一点趣闻：大多数物理学家并不使用自由熵或自由熵密度——其原因植根于热力学史，可以追溯到 Carnot 和 Clausius——而使用自由能及相应的自由能密度，它们与自由熵相差一个 $-\beta^{-1}$ 的因子。在 Curie–Weiss 模型中，这给出

$$\begin{aligned} f_N(\beta,h) &=: -\frac{1}{\beta N}\log Z_N(\beta,h) \quad \left(=-\frac{1}{\beta}\Phi_N(\beta,h)\right), \\ f(\beta,h) &=: \lim_{N\to\infty} f_N(\beta,h) = \min_m f(m,\beta,h), \\ f(m,\beta,h) &=: -\frac{1}{2}m^2 - hm - \frac{1}{\beta}H(m) \quad \left(=-\frac{1}{\beta}\phi(m)\right). \end{aligned}$$

物理学家（自 Clausius 以来）在对数前使用因子 $-\beta^{-1}$ 来定义自由能，这一事实对许多数学家而言似乎是个记号问题：他们完全不理解为何要为一个微不足道的负号费心。因此，许多人干脆把 $\Phi(\beta,h)$ 称作自由能密度（更糟糕的是，有时使用气体理论中的“压力”一词），这恐怕会让 Clausius 在九泉之下不得安宁。数学家还经常将 Hamiltonian 定义为与物理学家所用形式相差一个整体负号。由于本专著不涉及物理学中的实际应用，我们或许可以原谅这些坏习惯。不过，我们将尽量使用正确术语，这样例如就不会“最大化”能量和“最小化”熵！

1.2.1 自由熵的导数

现在讨论，知道自由熵实际上如何使我们能够重新发现已经讨论过的全部现象。首先注意，对于任何有限的 N，自由熵是磁化强度 $\bar{S}$ 的（连通）矩的生成泛函。用 $\langle\cdot\rangle_N$ 表示关于 Boltzmann 测度的平均，并回忆

$$Z_N(\beta,h)=\sum_{\mathbf{S}\in\{-1,1\}^N} e^{-\beta\mathcal{H}_N^0+\beta Nh\bar{S}},$$

我们有

$$\frac{1}{\beta}\frac{\partial}{\partial h}\Phi_N(\beta,h)=\frac{\partial}{\partial h}\frac{1}{\beta N}\log Z_N(\beta,h)=\sum_{\mathbf{S}\in\{-1,1\}^N}\frac{\bar{S}e^{-\beta\mathcal{H}_N}}{Z_N(\beta,h)}=\langle\bar{S}\rangle_N=m_N. \tag{1.10}$$

这也说明了为何在推导开始时引入外磁场 h 是有用的：我们可以通过对 h 求导获得磁化强度的矩，二阶导数给出方差，等等。然而，在取 $N\to\infty$ 极限后这一关系是否成立，远不是显然的：交换极限与导数的数学条件并不平凡。事实上，只有远离相变点时才能这样做，在此情况下它由自由熵的凸性得出。考察对 h 的二阶导数可得

$$\frac{1}{\beta}\frac{\partial^2}{\partial h^2}\Phi_N(\beta,h)=\frac{\partial}{\partial h}\sum_{\mathbf{S}\in\{-1,1\}^N}\frac{\bar{S}e^{-\beta\mathcal{H}_N}}{Z_N(\beta,h)}=N\beta\big(\langle\bar{S}^2\rangle_N-\langle\bar{S}\rangle_N^2\big)\geq 0. \tag{1.11}$$

因此 Φ_N 是凸函数。这个结果在统计物理语境中也称为涨落耗散定理。关于凸函数列 f_n 在 $n\to\infty$ 时极限的一个基本定理告诉我们：如果对所有 x 均有 $f_n(x)\to f(x)$，且 $f_n(x)$ 是凸的，那么对 $f(x)$ 可微的所有 x，有 $f_n'(x)\to f'(x)$。远离自由熵具有奇异性的相变点时，渐近自由熵的导数因此给出渐近磁化强度。让我们检查这一点。我们知道 $\Phi(\beta,h)=\phi(m^*(h,\beta))$，因此写出

$$\frac{1}{\beta}\frac{\partial}{\partial h}\Phi(\beta,h)=m^*(h,\beta)+\left.\frac{\partial\phi}{\partial m}\right|_{m^*}\frac{\partial m^*}{\partial h}=m^*(h,\beta), \tag{1.12}$$

因为 $\phi(m)$ 的导数在 m^* 处为零。自由熵的导数由此如预期那样给出了平衡磁化强度 m^*。

1.2.2 Legendre 变换

从另一种富有启发性的方式看待这个问题，需要使用杰出的法国数学家 Laplace 和 Legendre 所提出的两个重要数学事实。首先陈述计算积分时十分有用的 Laplace 方法。

定理 2 (Laplace 方法)**.** *假设 $f(x)$ 在 $[a,b]$ 上二次连续可微，且存在唯一点 $x_0\in(a,b)$，使得*

$$f(x_0)=\max_{x\in[a,b]}f(x),\qquad\qquad f''(x_0)<0,$$

则

$$\lim_{n\to\infty} \frac{\int_a^b e^{nf(x)}\,dx}{e^{nf(x_0)}\sqrt{\frac{2\pi}{n(-f''(x_0))}}} = 1,$$

特别地，

$$\lim_{n\to\infty} \frac{1}{n}\log \int_a^b e^{nf(x)}\,dx = f(x_0),$$

$$\lim_{n\to\infty} \frac{\int_a^b g(x)e^{nf(x)}\,dx}{\int_a^b e^{nf(x)}\,dx} = g(x_0). \tag{1.13}$$

译注（条件说明）： 原文式 (1.13) 未给出 g 的假设。该比值极限对任意 g 并不自动成立；通常需要 g 满足适当可积条件并在 x_0 处连续等条件。这里保留原式，条件待严格核实。

这些公式由 Laplace 于 1774 年在其基础性著作《Mémoire sur la probabilité des causes par les évènements》中证明；与大偏差原理结合后，它们具有深远影响。

考虑零场（$h=0$）的 Curie–Weiss 模型。由定义，我们有

$$\begin{aligned}\mathbb{P}(\bar{S}=m;h=0) &= \frac{\sum_{\mathbf{s}\in\{-1,1\}^N} e^{-\beta\mathcal{H}_N^0}\mathbf{1}(\bar{S}=m)}{Z_N(\beta,h=0)} \\ &= \frac{\sum_{\mathbf{s}\in\{-1,1\}^N} e^{-\beta\mathcal{H}_N^0}\mathbf{1}(\bar{S}=m)}{e^{N\log\Phi_N(\beta,0)}} \underset{N\to\infty}{\asymp} e^{-NI_0^*(m)},\end{aligned}$$

其中将零外场下真正的大偏差率记作 $I_0^*(m)$。即使不知道 $I_0^*(m)$ 的实际表达式，仅仅假设这一大偏差原理成立，也能得到深刻结论。事实上，我们可以将存在外场时系统的总配分和写成对 m 的可能取值的 Laplace 积分。使用 $\mathcal{H}_N = \mathcal{H}_N^0 - Nh\bar{S}$，有

$$\begin{aligned}Z_N(\beta,h) &= \sum_{m\in\mathcal{S}_N}\left(\sum_{\mathbf{s}\in\{-1,1\}^N} e^{-\beta\mathcal{H}_N^0}\mathbf{1}(\bar{S}=m)\right)e^{N\beta hm} \\ &\underset{N\to\infty}{\asymp} \int_{-1}^{1} dm\, e^{N(\Phi(\beta,0)-I_0^*(m,\beta)+\beta hm)}.\end{aligned} \tag{1.14}$$

此时，对 $Z_N(\beta,h)$ 的极限应用 Laplace 方法，便自动得到

$$\Phi(\beta,h)-\Phi(\beta,0) = \max_m[\beta hm - I_0^*(m)] = \phi(m^*).$$

因此，我们获得了一个非常一般的关系：有场系统的自由熵与（无场）大偏差率 $I_0^*(m)$ 通过 Legendre 变换联系起来：

$$\Phi(\beta,h)-\Phi(\beta,0) = \max_m[\beta hm - I_0^*(m)].$$

事实上，Legendre 变换理论还告诉我们更多：如果进一步对 $\Phi(\beta,h)$ 取 Legendre 变换，就可以（几乎）恢复真实的率 $I_0^*(m)$。定义

$$I_0(m) = \max_h[\beta hm - \Phi(\beta,h)] + \Phi(\beta,0),$$

那么 Legendre 变换的一个基本性质表明，$I_0(m)$ 是 $I_0^*(m)$ 的凸包。因此，即使仅仅对自由熵作“Legendre 变换”，我们也能恢复大偏差率。我们再次看到，一切都可以通过知道自由熵 $\Phi(\beta, h)$ 来计算。自由熵确实就是你所需要的一切。

不过请注意，用这种技术计算大偏差率的能力存在根本限制。由于只能恢复真实率的凸包，如果真实率不是凸的，就会有一部分曲线无法得到！图 1.5 说明了这一点：我们只能得到 $I_0^*(m)$ 与凸包 $I_0(m)$ 重合的部分（这个集合称为 $I_0^*(m)$ 的“暴露点”），而其他点只给出一个上界。这些考虑在统计力学中是经典的，是“系综等价”以及推导热力学（实际上不过是 Legendre 变换）的基础。

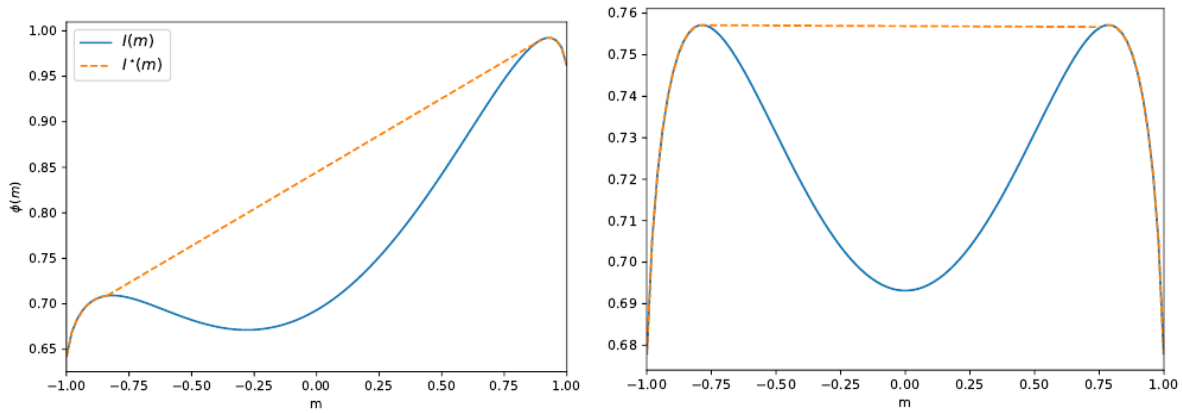


图 1.5: 真实大偏差率 $I(m)$ 及连续两次 Legendre 变换得到的函数 $I^*(m)$。$I^*(m)$ 是 $I(m)$ 的凸包。两个函数在所有“暴露点”上重合，在这些点切线不同于曲线；但在未被“暴露”的虚线区域它们不同。Legendre 变换只能对暴露点计算精确的大偏差率，对其他点则给出上界。

1.2.3 Gärtner–Ellis 定理

上述内容也可以使用现代大偏差理论的语言严格表述。特别是，Gärtner–Ellis 定理以十分一般的方式将大偏差率与配分和的 Legendre 变换联系起来：

定理 3 (Gärtner–Ellis，非正式表述)**.** 如果

$$\lambda(k) = \lim_{N\to\infty} \frac{1}{N} \log \mathbb{E}\big(e^{NkA_N}\big)$$

存在且对所有 $k \in \mathbb{R}$ 可微，那么定义

$$I(a) = \sup_k (ka - \lambda(k)),$$

我们有大偏差原理

$$\lim_{N\to\infty} \frac{1}{N} \log \mathbb{P}(A_N = a) \le -I(a),$$

并且对暴露点取等号：

$$\lim_{N\to\infty} \frac{1}{N} \log \mathbb{P}(A_N = a) = -I(a) \qquad \forall a \in \{\text{暴露点}\}.$$

在 Curie–Weiss 模型中，与先前推导的联系是直接的：考虑无场模型（即 $h=0$），令 $A_N=\bar{S}$ 为系统中的平均磁化强度。该定理（在这一特殊情形下称为 Cramér 定理）于是告诉我们需要计算

$$\lambda(k)=\lim_{N\to\infty}\frac{1}{N}\log\sum_{\mathbf{s}}\frac{1}{Z_N}e^{-\beta\mathcal{H}_N^0+Nk\bar{S}}=\lim_{N\to\infty}\big(\Phi_N(\beta,h=k/\beta)-\Phi_N(\beta,h=0)\big),$$

因此可以认出

$$\lambda(k)=\max_m\phi(m,h=k/\beta)=\max_m I(m)+\beta hm,$$

而（零场下）磁化强度的率函数由下式给出：

$$I(m)=\max_k[km-\lambda(k)].$$

根据 Legendre 变换的性质，$I(m)$ 确实由 $\phi(m,0)$ 的凸包给出，正如预期。

1.3 工具箱：Gibbs 自由熵与变分方法

我们不能期望配分和总是如此容易计算，因此值得学习一些技巧。下面这一基本结果是统计物理中许多分析及实践方法的根基，在机器学习中也得到广泛应用：

定理 4 (Gibbs 变分方法)**.** *考虑 Hamiltonian $\mathcal{H}_N(\mathbf{x})$，其中 $\mathbf{x}\in\mathbb{R}^N$，及其对应的 Boltzmann–Gibbs 测度 $P^{\mathrm{Gibbs}}(\mathbf{x})=e^{-\beta\mathcal{H}_N(\mathbf{x})}/Z_N(\beta)$。给定 $\mathbb{R}^N$ 上任意概率分布 $Q(\mathbf{x})$ 及其熵 $S[Q]=-\langle\log Q\rangle_Q$，定义 Gibbs 泛函*

$$N\phi^{\mathrm{Gibbs}}(Q)=:S[Q]-\beta\langle\mathcal{H}_N\rangle_Q,$$

其中 $\langle\cdot\rangle_Q$ 表示关于分布 Q 的期望。那么

$$\forall Q,\qquad \Phi_N(\beta)=\frac{1}{N}\log Z_N(\beta)\geq\phi^{\mathrm{Gibbs}}(Q),$$

当 $Q=P^{\mathrm{Gibbs}}$ 时取等号。

我们先证明一个更简单的结果。引入下列称为 Kullback–Leibler 散度（或“相对熵”）的量，用来度量两个分布 $P(\mathbf{x})$ 和 $Q(\mathbf{x})$ 有多大差异：

$$D_{\mathrm{KL}}(P\|Q)=:\int d\mathbf{x}\,P(\mathbf{x})\log\frac{P(\mathbf{x})}{Q(\mathbf{x})}.$$

可以证明如下引理：

引理 3 (Gibbs 不等式)**.** *$D_{\mathrm{KL}}(P\|Q)\geq 0$，当且仅当 $P=Q$ 几乎处处成立时取等号。*

证明. 对于任意标量 $u\in\mathbb{R}_+$，有 $\log u\leq u-1$，当 $u=1$ 时取等号。因此

$$\begin{aligned}-D_{\mathrm{KL}}(P\|Q)&=\int d\mathbf{x}\,P(\mathbf{x})\log\frac{Q(\mathbf{x})}{P(\mathbf{x})}\\&\leq\int d\mathbf{x}\,P(\mathbf{x})\left(\frac{Q(\mathbf{x})}{P(\mathbf{x})}-1\right)=\int d\mathbf{x}\,Q(\mathbf{x})-\int d\mathbf{x}\,P(\mathbf{x})=1-1=0.\end{aligned}$$

由于除 $u=1$ 外均有 $\log u<u-1$，除非 $P=Q$ 几乎处处成立，否则不等式严格成立。 □

接下来，利用 Kullback–Leibler 散度写出 Gibbs 自由熵与实际熵之间的差：

引理 4. 将 *Boltzmann–Gibbs* 概率分布记作 $P^{\mathrm{Gibbs}}(\mathbf{x}) = e^{-\beta\mathcal{H}(\mathbf{x})}/Z_N$，并将任意分布记作 Q，则

$$N\Phi_N = N\phi^{\mathrm{Gibbs}}(Q) + D_{\mathrm{KL}}(Q\|P^{\mathrm{Gibbs}}).$$

证明. 证明直接应用散度定义：

$$\begin{aligned}
\langle \log P^{\mathrm{Gibbs}}\rangle_Q &= -\beta\langle \mathcal{H}_N\rangle_Q - \log Z_N,\\
\langle \log P^{\mathrm{Gibbs}}\rangle_Q - \langle \log Q\rangle_Q &= -\beta\langle \mathcal{H}_N\rangle_Q - N\Phi_N - \langle \log Q\rangle_Q,\\
-D_{\mathrm{KL}}(Q\|P^{\mathrm{Gibbs}}) &= N\phi^{\mathrm{Gibbs}}(Q) - N\Phi_N,\\
N\Phi_N &= N\phi^{\mathrm{Gibbs}}(Q) + D_{\mathrm{KL}}(Q\|P^{\mathrm{Gibbs}}).
\end{aligned}$$

□

引理 3 与引理 4 共同蕴含定理 4。为什么这很有趣? 基本上，它给我们提供了通过使用许多“试探”分布并挑选具有最大自由熵者，来近似配分和（以及真实分布）的方法。自统计物理和量子物理诞生以来，这一方法以许多名字被无数次使用（例如 “Gibbs–Bogoliubov–Feynman”），也是 Bayesian 统计与机器学习中许多应用的根基；在后一种情形下，Gibbs 自由熵称为证据下界，简称 ELBO。

让我们看看它如何用于 Curie–Weiss 模型。我们可以尝试的最简单方法是对所有自旋取相同的因子化分布：

$$Q(\mathbf{S}) = \prod_i Q_i(S_i) = \prod_i \left(\frac{1+m}{2}\delta(S_i-1) + \frac{1-m}{2}\delta(S_i+1)\right). \tag{1.15}$$

于是，可以将 Gibbs 自由熵密度写成

$$\phi^{\mathrm{Gibbs}}(Q) = \beta\left\langle \frac{\bar{S}^2}{2} + h\bar{S}\right\rangle_Q + \frac{1}{N}\sum_i H(Q_i) \tag{1.16}$$

$$= \frac{\beta m^2}{2} + \beta h m + H(m), \tag{1.17}$$

其中 $H(m)$ 是二元熵。通过这一简单的变分试探，我们在任意固定 m 下重新得到正确的自由熵。

1.4 工具箱：空腔法

这里，我们将看到另一种重要方法：空腔技巧。它将是本课程中许多计算的基础。整个思想基于以下问题：向系统中加入一个变量时会发生什么？物理学家喜欢形象化：可以想象一个由 N 个变量构成的系统，在其中开一个小“洞”或“空腔”，再小心地加入一个变量，空腔法因而得名。

让我们比较具有 N 和 $N+1$ 个变量的两个 Hamiltonian，看看它如何起作用。将新自旋编号为“0”，对于逆温度 β' 和场 h' 下的系统，我们有

$$-\beta'\mathcal{H}_{N+1} = \frac{\beta'}{2}(N+1)\left(\frac{S_0+\sum_i S_i}{N+1}\right)^2 + \beta' h'\left(S_0 + \sum_i S_i\right)$$

$$= \frac{\beta'}{2(N+1)} + \frac{\beta'}{2}\frac{N^2}{N+1}\left(\frac{\sum_i S_i}{N}\right)^2 + \beta' S_0 \frac{N}{N+1}\left(\frac{\sum_i S_i}{N}\right) + \beta' h' \sum_i S_i + \beta' h' S_0. \tag{1.18}$$

如果定义 $\beta' = \beta(N+1)/N$，并令新场 $h' = hN/(N+1)$，则得到

$$\begin{aligned} -\beta' \mathcal{H}_{N+1}(h') &= \mathrm{cst} + \frac{\beta}{2} N \left(\frac{\sum_i S_i}{N}\right)^2 + \beta S_0 \left(\frac{\sum_i S_i}{N}\right) + \beta h \sum_i S_i + \beta h S_0 \\ &= \mathrm{cst} - \beta \mathcal{H}_N + \beta S_0 \left(\frac{\sum_i S_i}{N}\right) + \beta h S_0. \end{aligned}$$

于是，我们有两个系统：一个有 $N+1$ 个自旋，温度与场为 (β', h')；另一个有 N 个自旋，温度与场为 (β, h)。我们刚推导的关系使得新系统中关于第 $N+1$ 个变量的期望，可以容易地作为旧系统中求和的函数来计算。事实上，可以直接写出新变量的期望：

$$\begin{aligned} \langle S_0 \rangle_{N+1,\beta'} &= \frac{\sum_{S_0,\mathbf{s}} S_0 e^{-\beta' \mathcal{H}'_{N+1}}}{\sum_{S_0,\mathbf{s}} e^{-\beta' \mathcal{H}'_{N+1}}} = \frac{\sum_{\mathbf{s}} \sum_{S_0} S_0 e^{-\beta \mathcal{H}_N + \beta S_0 \bar{S} + \beta h S_0}}{\sum_{\mathbf{s}} \sum_{S_0} e^{-\beta \mathcal{H}_N + \beta S_0 \bar{S} + \beta h S_0}} \\ &= \frac{\langle \sinh(\beta(\bar{S}+h)) \rangle_{N,\beta}}{\langle \cosh(\beta(\bar{S}+h)) \rangle_{N,\beta}}. \end{aligned}$$

像物理学家会做的那样，假设 $\bar{S}$ 集中到确定值 m^*（至少在相共存线之外），并假设当 N 足够大时，N 与 $N+1$ 系统的 m^* 应当相同（正如它应该的那样），我们立刻得到

$$\langle S_0 \rangle_{N+1,\beta'} = \frac{\langle \sinh(\beta(\bar{S}+h)) \rangle_{N,\beta}}{\langle \cosh(\beta(\bar{S}+h)) \rangle_{N,\beta}} \approx \frac{\sinh(\beta(m^*+h))}{\cosh(\beta(m^*+h))} = \tanh\bigl(\beta(m^*+h)\bigr).$$

当 $N \to \infty$ 时，β 与 β' 的差消失，我们重新得到平均场方程：

$$m^* = \tanh\bigl(\beta(m^*+h)\bigr).$$

我们还可以通过类似的空腔论证恢复自由能。首先注意

$$\frac{1}{N}\log Z_N = \frac{1}{N}\log\left(\frac{Z_N}{Z_{N-1}} Z_{N-1}\right) = \frac{1}{N}\log\left(\frac{Z_N}{Z_{N-1}}\frac{Z_{N-1}}{Z_{N-2}}\cdots\frac{Z_1}{1}\right) = \frac{1}{N}\sum_{n=0}^{N} \log\frac{Z_{n+1}}{Z_n}, \tag{1.19}$$

因此（可以利用 Cesàro 求和作严格论证，见附录 1.C），

$$\Phi(\beta, h) = \lim_{N\to\infty} \log \frac{Z_{N+1}(\beta, h)}{Z_N(\beta, h)}.$$

但要注意，此计算中 N 与 $N+1$ 系统的 β 应当相同。从式 (1.18) 出发，确保保留所有不是 $o(1)$ 的项，可写出

$$\begin{aligned} -\beta \mathcal{H}_{N+1} &= o(1) + \frac{\beta}{2}(N - 1 + o(1)) \left(\frac{\sum_i S_i}{N}\right)^2 + \beta S_0 (1 + o(1)) \left(\frac{\sum_i S_i}{N}\right) + \beta h \sum_i S_i + \beta h S_0 \\ &= o(1) - \beta \mathcal{H}_N - \frac{\beta}{2}\left(\frac{\sum_i S_i}{N}\right)^2 + \beta S_0 \left(\frac{\sum_i S_i}{N}\right) + \beta h S_0. \end{aligned} \tag{1.20}$$

注意其中出现的 $-\beta\bar{S}^2/2$ 项；如果不够谨慎，我们本可能忽略它。在前一个计算中没有保留这一项，因为可以把它纳入 β'；它在大 N 极限中没有造成差别，并且可以以对 β 作一个微小 $o(1)$

改变为代价吸收到归一化中。然而，这里需要计算的是 $O(1)$ 的 Z_{N+1}/Z_N，所以必须留意任何常数修正。现在终于可以计算[4]

$$\frac{Z_{N+1}}{Z_N} = \left\langle e^{-\frac{\beta}{2}\bar{S}^2}\, 2\cosh\bigl(\beta(\bar{S}+h)\bigr)\right\rangle_{N,\beta}. \tag{1.21}$$

现在使用 $\bar{S}$ 集中于 m^* 的性质，取对数得到

$$\Phi(\beta,h) = -\beta\frac{(m^*)^2}{2} + \log\left[2\cosh\bigl(\beta(m^*+h)\bigr)\right]. \tag{1.22}$$

这看起来可能有些奇怪，因为它与先前的表达式不同！事实上，现在我们发现

$$\Phi(\beta,h) = \max_m \tilde{\phi}(m), \qquad \tilde{\phi}(m) =: -\beta\frac{m^2}{2} + \log 2\cosh\bigl(\beta(m+h)\bigr). \tag{1.23}$$

我们的确是在取最大值，因为 $\tilde{\phi}(m)$ 对 m 的导数给出 $m^* = \tanh(\beta(m^*+h))$。我们是否犯了错误？没有！虽然 $\tilde{\phi}(m)$ 与 $\phi(m)$ 不同，但在它们的任意极值处二者取值相同，简单作图即可验证。事实上，可以解析地证明它们的不动点相同：记住 $m^* = \tanh(\beta(m^*+h))$，因此 $\beta(m^*+h) = \operatorname{atanh}(m^*)$；使用恒等式

$$\log[2\cosh(\operatorname{atanh}(x))] - x\operatorname{atanh}(x) = H(x) = -\left(\frac{1+x}{2}\log\frac{1+x}{2} + \frac{1-x}{2}\log\frac{1-x}{2}\right),$$

得到

$$\begin{aligned}
\tilde{\phi}(m^*) &= -\beta\frac{(m^*)^2}{2} + \log[2\cosh(\beta(m^*+h))] \\
&= -\beta\frac{(m^*)^2}{2} + \log[2\cosh(\operatorname{atanh}(m^*))] \\
&= -\beta\frac{(m^*)^2}{2} + m^*\operatorname{atanh}(m^*) + H(m^*) \\
&= -\beta\frac{(m^*)^2}{2} + \beta(m^*)^2 + \beta m^* h + H(m^*) = \phi(m^*).
\end{aligned}$$

然而，不应假定最后这个表达式 $\tilde{\phi}(m)$ 是正确的大偏差量：它不是。请读者检查 $\Phi(\beta,h)$ 的 Legendre 变换确实会如预期那样给出正确的大偏差函数 ϕ。正如附录 1.C 所展示的，所有这些论证都可以变得完全严格。这是数学家可以用来证明本专著所讨论某些结果的非常重要的工具之一。

1.5 工具箱：“场论式”计算

为了结束本讲，学习一种物理学家经常使用的技巧也很有价值；它将是后续各章所有副本计算的核心。在简单的 Curie–Weiss 模型中学习它或许是个好主意。再次写出 Hamiltonian

$$\mathcal{H}_N^0 = -\frac{1}{N}\sum_{i<j} S_i S_j \approx -\frac{1}{2N}\sum_{i,j} S_i S_j - \sum_i S_i,$$

以及配分和

$$Z_N = \sum_{\mathbf{S}} e^{\frac{N\beta}{2}\left(\frac{\sum_j S_j}{N}\right)^2 + N\beta h\frac{\sum_i S_i}{N}}.$$

[4]这里作一个稍后讨论稀疏图空腔法时有用的备注：新 Hamiltonian 除旧 Hamiltonian 外还有两项：一个是作为 S_0 函数的“位点”项，另一个是“连接”项，其出现是因为除了加入一个自旋，我们还向系统加入了 N 条连接。这将是一种普遍性质。

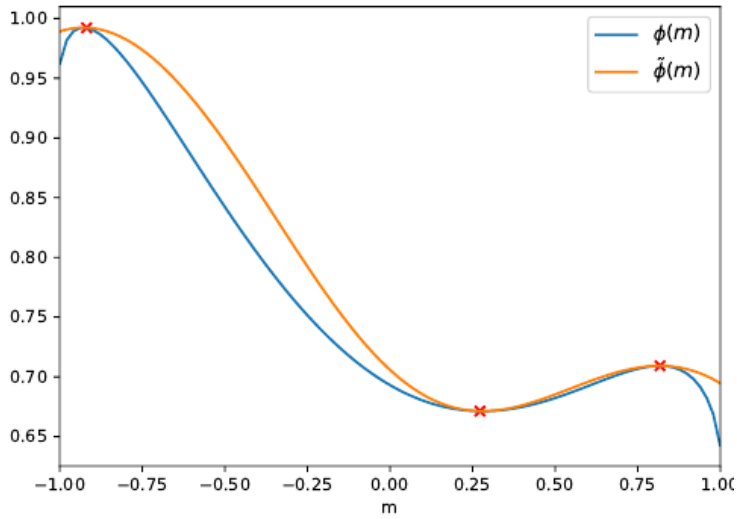


图 1.6: 函数 $\phi(m)$（式 (1.4)）与 $\tilde{\phi}(m)$（式 (1.23)）不同，但在它们的所有极值处重合。

现在，假装我们不知道如何计算二项系数 $\Omega(m)$。我们将使用所谓的“Dirac–Fourier”方法，它从以下 δ“函数”恒等式出发：

$$\int du\, f(u)\delta(u-x) = f(x).$$

在这里，物理学家实际上会使用该恒等式的以下版本：

$$\begin{aligned}\int dm\, f(m)\delta(Nm-x) &= \int dm\, \delta\left(N\left(m-\frac{x}{N}\right)\right) f(m)\\ &= \frac{1}{N}\int dm\, f(m)\delta\left(m-\frac{x}{N}\right) = \frac{1}{N} f\left(\frac{x}{N}\right),\end{aligned}$$

但请注意，额外的 $1/N$ 项并不重要，因为我们取对数并除以 N：因此它在渐近意义上不会产生差异。接着写出

$$\begin{aligned}Z_N &= \sum_{\mathbf{S}} e^{-\beta\mathcal{H}_N} = N\sum_{\mathbf{S}}\int dm\,\delta\left(Nm-\sum_j S_j\right) e^{\frac{N\beta}{2}m^2+N\beta hm}\\ &= N\int dm\, e^{\frac{N\beta}{2}m^2+\beta hmN}\sum_{\mathbf{S}}\delta\left(Nm-\sum_j S_j\right).\end{aligned}$$

我们看出需要计算固定 m 下的熵。再次假装我们不会计算它（目的是不借助任何组合计算来完成）。改用 δ“函数”（它实际上是一个分布）的 Fourier 变换，可得

$$Z_N = N\int dm\int d\lambda\, e^{\frac{N\beta}{2}m^2+\beta hmN}\sum_{\mathbf{S}} e^{i2\pi\lambda N\left(m-\frac{\sum_j S_j}{N}\right)}.$$

我们不喜欢显式保留 i，于是写 $\hat{m} = i2\pi\lambda$ 并在复平面上积分：

$$Z_N = 2iN\pi\int_{-1}^{1} dm\int_{-i2\pi\infty}^{i2\pi\infty} d\hat{m}\, e^{\frac{N\beta}{2}m^2+\beta hNm+N\hat{m}m}\sum_{\mathbf{S}} e^{-\hat{m}\sum_j S_j}$$

$$= 2iN\pi \int_{-1}^{1} dm \int_{-i2\pi\infty}^{i2\pi\infty} d\hat{m}\, e^{N\frac{\beta}{2}m^2 + N\beta hm + N\hat{m}m} (2\cosh\hat{m})^N.$$

我们只对对数密度感兴趣，因此写成

$$\frac{\log Z_N}{N} = \frac{1}{N}\log\left\{\int_{-1}^{1} dm \int_{-i2\pi\infty}^{i2\pi\infty} d\hat{m}\, e^{\frac{N\beta}{2}m^2 + N\beta hm + N\hat{m}m + N\log 2 + N\log\cosh\hat{m}}\right\} + o(1).$$

我们以引入积分为代价，摆脱了组合求和。然而，事实表明这些积分非常容易，至少在 N 很大时如此。技巧是使用 Cauchy 定理变形关于 $\hat{m}$ 的轮廓积分，让路径恰好通过复平面中的鞍点。这称为鞍点法，是 Laplace 方法到复平面的推广。习题 1.3 给出了更多信息；鞍点法告诉我们，对于此类积分，

$$\Phi(\beta, h) = \lim_{N\to\infty} \frac{\log Z}{N} = \operatorname{extr}_{m,\hat{m}} g(m, \hat{m}),$$
$$g(m, \hat{m}) = \frac{\beta}{2}m^2 + \beta hm + \hat{m}m + \log 2 + \log\cosh\hat{m}.$$

换言之，复域上的二维积分被简单得多的求导代替：我们只需找到 $g(m, \hat{m})$ 的极值！

这个表达式与之前得到的表达式是否一致？对 $\hat{m}$ 求导：极值条件要求 $m = -\tanh\hat{m}$，即 $\hat{m} = -\tanh^{-1} m$。将其代入后，最终得到

$$g(m) = \frac{\beta}{2}m^2 + \beta hm - m\tanh^{-1} m + \log\big[2\cosh(\tanh^{-1} m)\big].$$

它看起来与我们熟悉的 $\phi(m)$ 并不直接相似，但通过恒等式

$$\log\big[2\cosh(\operatorname{atanh} m)\big] - m\operatorname{atanh} m = H(m),$$

我们重新得到

$$g(m) = \phi(\beta, m) + \beta hm = \frac{\beta}{2}m^2 + \beta hm + H(m) = \phi(m, \beta),$$

以及应有的 $\Phi(\beta, h) = \operatorname{extr}_m \phi(\beta, m)$。

但值得注意的是，大多数物理学家选择用稍有不同但等价的方式书写。事实上，再次从

$$g(m, \hat{m}) = \frac{\beta}{2}m^2 + \beta hm + \hat{m}m + \log 2 + \log\cosh\hat{m}$$

出发，典型的物理学家会施加 $\hat{m} = -\beta(m + h)$，而不是 $m = -\tanh\hat{m}$。由于这样更方便，他们随后消去 $\hat{m}$ 而非 m，并写成

$$\Phi(\beta, h) = \operatorname{extr}_m \left[-\frac{\beta}{2}m^2 + \log\big(2\cosh\beta(m + h)\big)\right] = \max\tilde{\phi}(m, h, \beta).$$

正如我们在上一节空腔计算中所看到的，这没有问题，因为这个公式同样正确。事实上，这种方法能够得到两种形式，令人安心。

参考文献说明

Curie–Weiss 模型受到法国人 Pierre Curie（Curie, 1895）与 Pierre Weiss（Weiss, 1907）开创性工作的启发。Kadanoff（2009）很好地描述了物理学中平均场模型与变分方法的历史。Curie–

Weiss 模型严格解的阐述遵循 Dembo 等（2010a）。Laplace 方法由 Pierre Simon de Laplace 在其 1774 年革命性著作（Laplace, 1774）中提出，他在其中创立了统计学。鞍点法最早由 Debye（1009）发表，而 Debye 又将其归功于 Riemann（1863）的一篇未发表笔记。关于大偏差的经典参考文献是 Dembo 等（1996）。Touchette（2009）的精彩综述介绍了统计力学的大偏差方法，推荐物理学家阅读。Wainwright 和 Jordan（2008）非常详细地讨论了统计学和机器学习中的变分方法。

1.6 习题

习题 1.1：二项系数的界

我们希望证明本章开头推导中使用的二项系数界：

$$\frac{e^{nH(k/m)}}{n+1} < \binom{n}{k} = \frac{n!}{k!(n-k)!} < e^{nH(k/n)},$$

其中 $H(p) = -p\log p - (1-p)\log(1-p)$ 是二项熵（本章中我们使用 $p = (1+m)/2$）。

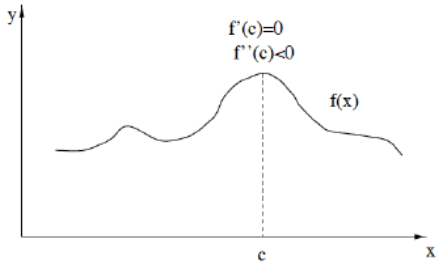
1. 使用二项式定理证明，对任意 $0 < p < 1$，
$$1 = \sum_{i=0}^{n} \binom{n}{i} (1-p)^i p^{n-i}.$$
2. 使用 p 的一个特定值，并只保留求和中的一项，证明 $\binom{n}{k} < e^{nH(k/n)}$。
3. 如果从正结果概率为 $p = k/n$ 的 Bernoulli 变量中抽取 n 次，正结果出现次数最可能的值是多少？由此推出 $(n+1)\binom{n}{k} > e^{nH(k/n)}$。

习题 1.2：Laplace 方法

本习题关心下列实积分在 $\lambda \to \infty$ 时的渐近行为：

$$I(\lambda) = \int_a^b dt\, h(t) e^{\lambda f(t)}.$$

1. 直观而言，区间 $[a,b]$ 的哪些区域对 $I(\lambda)$ 的值贡献更大？
2. 假设函数 $f(t)$ 在点 $c \in [a,b]$ 处有唯一全局最大值，满足 $f''(c) < 0$，并假设 $h(c) \neq 0$。对 f 作 Taylor 展开，说明对于 $\lambda \gg 1$，我们预期积分行为如下：
$$I(\lambda) \underset{\lambda \gg 1}{=} \int_{c-\epsilon}^{c+\epsilon} dt\, h(c) e^{\lambda[f(c) + \frac{1}{2} f''(c)(t-c)^2]},$$
其中 $\epsilon > 0$ 是一个正但很小的实数。



3. 利用上述结果，推出

$$I(\lambda) \asymp \frac{h(c)e^{\lambda f(c)}}{\sqrt{-\lambda f''(c)}} \int_{\mathbb{R}} e^{-t^2}\, dt.$$

4. （高斯积分）证明 $\int_{\mathbb{R}} e^{-t^2}\, dt = \sqrt{\pi}$。

5. 推导 Laplace 公式：

$$\int_a^b dt\, h(t)e^{\lambda f(t)} \asymp \sqrt{\frac{2\pi}{-\lambda f''(c)}} e^{\lambda f(c)} h(c).$$

习题 1.3：鞍点法

鞍点法是 Laplace 方法到复平面的推广。和先前一样，我们寻求以下类型积分的渐近公式：

$$I(\lambda) = \int_\gamma dz\, h(z)e^{\lambda f(z)},$$

其中 $\gamma : [a, b] \to \mathbb{C}$ 是复平面 $\mathbb{C}$ 中的曲线，而 $\lambda > 0$ 是我们将取为较大的正实数。如果复函数 f 在连通开集 $\Omega \subset \mathbb{C}$ 上全纯，积分 $I(\lambda)$ 与曲线 γ 无关。因此，目标是明智地选择 γ。

第一部分：全纯函数的几何性质。 设 $f : \mathbb{C} \to \mathbb{C}$ 是全纯函数，对实数 $x, y \in \mathbb{R}$，令 $z = x+iy \in \mathbb{C}$。无损一般性地，可以写成 $f(z) = u(x, y) + iv(x, y)$，其中 $u, v : \mathbb{R}^2 \to \mathbb{R}$ 是实值函数。本习题旨在研究 f 在临界点 $f'(z_0) = 0$（$z_0 \in \mathbb{C}$）附近的性质。

1. 证明在临界点处 u 与 v 的梯度均为零。

2. 使用 Cauchy 积分公式，证明对于 f 全纯的开凸集 Ω 中所有 $z_0 = x_0 + iy_0$，以及所有包含在 Ω 内、以 z_0 为中心且半径 $r > 0$ 的圆，有

$$u(x_0, y_0) = \frac{1}{2\pi} \int_0^{2\pi} d\theta\, u(x_0 + r\cos\theta, y_0 + r\sin\theta),$$
$$v(x_0, y_0) = \frac{1}{2\pi} \int_0^{2\pi} d\theta\, v(x_0 + r\cos\theta, y_0 + r\sin\theta).$$

   这个结果在复分析中称为均值定理。

3. 推出 u 和 v 均不能在 Ω 内有局部极值（最大值或最小值）。因此所有临界点 $z_0 \in \Omega$ 都必然是 u 和 v 的鞍点。

4. 设 z_0 是满足 $f''(z_0) \neq 0$ 的临界点。利用 f 在 z_0 附近的 Taylor 展开，以及极分解 $f''(z_0) = \rho e^{i\alpha}$、$z - z_0 = re^{i\theta}$，找出在复平面中对应于 u 的两个最速下降方向的 $\theta \in [0, 2\pi)$ 值，并表示为 α 的函数。

第二部分：选择合适的曲线 γ。

1. γ 的哪些区域主导积分 $I(\lambda)$?

2. 设 z_0 是临界点 $f'(z_0) = 0$。解释为什么应选择 γ 沿实部 $\mathrm{Re}[f]$ 的最速下降方向经过 z_0。

3. 证明对于这样的 γ，可以将积分改写为

$$I(\lambda) = e^{i\lambda \operatorname{Im}[f(z_0)]} \int_\gamma dz\, h(z) e^{\lambda \operatorname{Re}[f(z)]}.$$

4. 令 $\gamma(t) = x(t) + iy(t)$（$t \in [a,b]$）是沿 $\operatorname{Re}[f]$ 最速下降方向经过 $z_0 = \gamma(t_0)$ 的曲线的参数化。令 $f(t) = f(\gamma(t))$、$h(t) = h(\gamma(t))$、$u(t) = \operatorname{Re}[f(t)]$、$v(t) = \operatorname{Im}[f(t)]$，证明问题归结为求值积分

$$\int_a^b dt\, \gamma'(t) h(t) e^{\lambda u(t)}.$$

第三部分：回到 Laplace 方法。

1. 假设 $h(t_0) \neq 0$，并注意我们可以选择使 $\gamma'(t_0) \neq 0$ 的参数化。使用 Laplace 方法证明，当 $\lambda \gg 1$ 时，$I(\lambda)$ 具有渐近展开

$$I(\lambda) \asymp h(t_0)\gamma'(t_0) \sqrt{\frac{2\pi}{-\lambda u''(t_0)}} e^{\lambda f(t_0)}.$$

2. 写出 $f(t)$ 对 t 的二阶导数，证明在临界点 z_0 处有

$$\frac{d^2 f(t_0)}{dt^2} = \gamma'(t_0)^2 \frac{d^2 f(z_0)}{dz^2}.$$

3. 证明二阶导数 $f''(t_0)$ 必然是负实数，并推出 $u''(t_0) = -|f''(z_0)||\gamma'(t_0)|^2$。

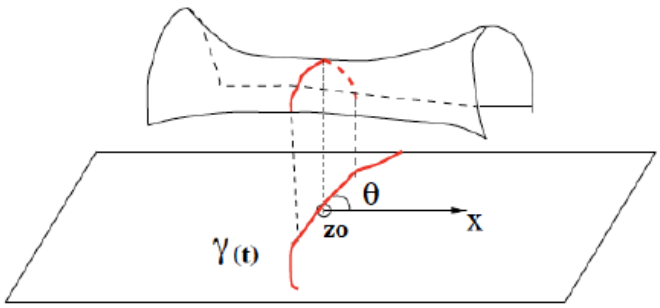
4. 设 θ 是曲线 γ 与实轴在临界点 z_0 处的夹角（见下图）。证明 $\gamma'(t_0) = |\gamma'(t_0)|e^{i\theta}$。

5. 令 $f''(z_0) = |f''(z_0)|e^{i\alpha}$，证明取决于曲线 γ 的方向，$\theta = \frac{1}{2}(\pi - \alpha)$ 或 $\theta = \frac{1}{2}(\pi - \alpha) + \pi$。

6. 推出

$$I(\lambda) \asymp \pm h(z_0) e^{\lambda f(z_0)} e^{i(\pi-\alpha)/2} \sqrt{\frac{2\pi}{\lambda |f''(z_0)|}} = h(z_0) e^{\lambda f(z_0)} \sqrt{\frac{2\pi}{-\lambda f''(z_0)}},$$

其中 $\pm$ 由最速下降曲线的方向给出。



习题 1.4：Metropolis–Hastings 算法

再次考虑 Curie–Weiss 模型的 Hamiltonian。从 Gibbs 概率分布

$$\mathbb{P}(\mathbf{S}=\mathbf{s};\beta,h)=\frac{\exp(-\beta\mathcal{H}_N(\mathbf{s};h))}{Z_N(\beta,h)} \tag{1.24}$$

采样 N 个自旋构型的一种非常实用的方法是 Monte Carlo–Markov 链（MCMC）方法，特别是 Metropolis–Hastings 算法。其工作方式如下：

1. 为 N 个自旋的值选择一个初始构型 $s_i=\pm1$，其中 $i=1,\dots,N$。
2. 随机选择一个自旋 i。计算当前能量 E_{now} 和翻转自旋 i（即 $S_i^{\text{new}}=-S_i^{\text{old}}$）后的能量 E_{flip}。
3. 在 $[0,1]$ 中均匀抽取一个数 r。如果 $r<e^{\beta(E_{\text{now}}-E_{\text{flip}})}$，则执行翻转（即 $S_i^{\text{new}}=-S_i^{\text{old}}$）；否则保持原状。
4. 返回步骤 2。

如果执行这一程序的时间足够长，就可以保证最终构型 $\mathbf{S}$ 以正确的概率被选取。

1. 编写程序实现 MCMC 动力学，从所有自旋均等于 $S_i=1$ 的构型开始。取 $h=0$、$\beta=1.2$，将动力学运行足够长的时间（例如尝试翻转自旋 $t_{\max}=100N$ 次），并监测单自旋磁化强度 $m=\sum_i S_i/N$ 随时间的变化。分别对 $N=10,50,100,200,1000$ 个自旋作图，并与 $N=\infty$ 的精确解比较。有何观察和结论？
2. 从所有自旋均等于 1 的构型开始，取 $h=-0.1$、$\beta=1.2$。再次监测单自旋磁化强度 $m=\sum_i s_i/N$ 随时间的变化。分别对 $N=10,50,100,200,1000$ 个自旋作图，并与 $N=\infty$ 的精确解比较。有何观察和结论？

习题 1.5：Glauber 算法

另一种从测度 (1.24) 采样的局部算法称为 Glauber 算法或热浴算法。其思想并非随机翻转一个自旋，而是使该自旋与其局部环境热化。

第一部分：算法。

1. 设 $\bar{S}=\frac{1}{N}\sum_{i=1}^{N}s_i$ 为 N 个自旋系统的总磁化强度。证明对于所有 $i=1,\dots,N$，在其他自旋均固定时，自旋满足 $S_i=\pm1$ 的概率为

$$\mathbb{P}(S_i=\pm1\mid\{S_j\}_{j\neq i})\equiv P_{\pm}=\frac{1\pm\tanh(\beta(\bar{S}+h))}{2}.$$

2. Glauber 算法定义如下：

   (a) 选择 N 个自旋的初始构型，计算对应的磁化强度 m_t 和能量 E_t。

   (b) 随机选择一个自旋 S_i，并均匀抽取随机数 $r\in[0,1]$。若 $r<P_+$，则设 $S_i=+1$，否则设 $S_i=-1$。更新能量和磁化强度。

   (c) 重复步骤 2 直至收敛。

   编写实现 Glauber 动力学的代码。使用相同参数重复习题 1.4 的第（a）和（b）项，比较动力学，并评论观察到的差异。

第二部分：从 Glauber 算法得到平均场方程。 现在从 Glauber 算法推导 Curie–Weiss 模型的平均场方程。

1. 令 m_t 表示时刻 t 的总磁化强度，定义 $P_{t,m} = \mathbb{P}(m_t = m)$。为简单起见，取 $\beta = 1$ 和 $h = 0$。证明对于 $\delta \ll 1$，可以写成

$$\begin{aligned} P_{t+\delta t,m} = {} & P_{t,m+\frac{2}{N}} \left\{ \frac{1}{2}\left(1 + m + \frac{2}{N}\right) \right\} \frac{1 - \tanh(m + 2/N)}{2} \\ & + P_{t,m-\frac{2}{N}} \left\{ \frac{1}{2}\left(1 - m + \frac{2}{N}\right) \right\} \frac{1}{2}\big(1 + \tanh(m - 2/N)\big) \\ & + P_{t,m} \left\{ \frac{1}{2}(1+m)\frac{1 + \tanh m}{2} + \frac{1}{2}(1-m)\frac{1 - \tanh m}{2} \right\}. \end{aligned}$$

   这称为主方程。

2. 定义关于 $P_{t,m}$ 的平均磁化强度 $\langle m(t) \rangle = \int dm\, m P_{t,m}$。利用上述主方程，证明可以得到期望磁化强度的方程：

$$\begin{aligned} \langle m(t+\delta t) \rangle = {} & \int P_{t,m+2/N} \left\{ \tfrac{1}{2}(1 + m + 2/N) \right\} \frac{1 - \tanh(m + 2/N)}{2}\, m\, dm \\ & + \int P_{t,m-2/N} \left\{ \tfrac{1}{2}(1 - m + 2/N) \right\} \frac{1 + \tanh(m - 2/N)}{2}\, m\, dm \\ & + \int P_{t,m} \left\{ \frac{1+m}{2}\frac{1 + \tanh m}{2} + \frac{1-m}{2}\frac{1 - \tanh m}{2} \right\} m\, dm. \end{aligned}$$

3. 在第一个积分中作变量代换 $m \to m + 2/N$，在第二个积分中作 $m \to m - 2/N$，并选择 $\delta = 1/N$，由此推出当 $N \to \infty$ 时，可以写出平均磁化强度的如下连续动力学：

$$\frac{d}{dt}\langle m(t) \rangle = -\langle m(t) \rangle + \tanh\langle m(t) \rangle.$$

4. 推出平稳期望磁化强度满足 Curie–Weiss 平均场方程，并推广到任意 β 与 h。

5. 现在可以重复上一题的实验，但使用理论常微分方程：从所有自旋等于 1 的构型开始，取不同的 h 和 β。Monte Carlo 链在哪些取值下会达到平衡值？何时会被困在自由熵 $\phi(m)$ 的伪最大值中？将理论预测与数值模拟比较。

习题 1.6：Potts 模型

Potts 模型是 Ising 模型的一种变体，其中可以有多于两个的状态：这里 Potts 自旋最多可取 q 个值。它是统计物理中最基本的模型之一。在全连接版本中，其 Hamiltonian 为

$$\mathcal{H} = \sum_{i,j} \frac{1}{N}(1 - \delta_{\sigma_i,\sigma_j}),$$

其中对所有 $i = 1, \ldots, N$，$\sigma_i = 1, \ldots, q$。

1. 使用第 1.3 节的变分方法，将 Potts 模型的 Gibbs 自由能写成处于状态 τ 的自旋比例 $\{\rho_\tau\}_{i=1,\ldots,N,\tau=1,\ldots,q}$ 的函数。

2. 通过对 Gibbs 自由能取极值，写出支配 $\{\rho_\tau\}$ 的平均场自洽方程，并进行数值求解。

3. 使用第 1.4 节的空腔方法，证明也可以通过这一方法恢复平均场自洽方程。

附录 1.A：统计物理术语

在这些讲义中，我们会经常采用统计物理的术语。对已经修过这一领域课程的人而言，这些术语很标准，但对于其他领域的初学者，它们往往令人困惑。

如引言所述，系统由一组自由度(d.o.f.)$\{x_i\}_{i\in I}$ 和一个 Hamiltonian 函数 $\mathcal{H}(\{x_i\}_{i\in I})$ 定义，该函数为每个自由度构型赋予能量或代价。例如，在 Curie–Weiss 模型中，自由度是由 $i=1,\dots,N$ 索引的自旋 $x_i\in\{-1,1\}$，其 Hamiltonian 由式 (1.1) 给出。但请注意，指标集 I 与状态空间 $\mathcal{X}$ 可以更一般。例如，第 6 章将讨论图着色问题：该系统的自由度定义在图 G 的节点上，可以取 q 个不同值，使得 $\mathcal{X}=\{1,\dots,q\}$。而在第 16 章，我们将研究状态空间可以不可数的推断问题，例如单层神经网络的权重。注意，我们甚至可以研究由不可数集合索引的系统，例如 $I\subset\mathbb{R}$；此时通常称自由度为场。

然而，本讲义只处理离散且有限（因而可数）的指标。因此，对构型 $\mathbf{x}\in\mathcal{X}^N$ 采用向量记号很方便，其中 $N\equiv|I|$ 称为系统大小。随系统大小 N 缩放的量通常称为广延量（数学上写作 $O_N(N)$），而不随系统大小缩放的量通常称为强度量（记为 $O_N(1)$）。典型广延量包括能量、熵和体积，典型强度量包括温度和压强。注意，通过考虑广延量的密度（除以 N），总可以得到强度量。系统大小无穷极限 $N\to\infty$ 称为热力学极限，统计力学的很大一部分工作致力于研究热力学极限下强度量的行为。

经典力学的目标是研究系统的微观性质，例如气体中每个分子的轨迹，或训练期间神经网络中每个神经元的动力学。相比之下，统计力学的目标是研究系统的宏观性质，即自由度的集体性质。在前面的例子中，气体的宏观性质包括平均能量、温度或压强，而神经网络的宏观性质是泛化误差。为了使这些概念更精确，统计物理在构型上定义一个系综，它只是所有可能构型组成的空间上的概率测度。可以为同一系统定义不同的系综，但本讲义主要关注正则系综，它由 Boltzmann–Gibbs 分布定义：

$$\mathbb{P}(\mathbf{X}=\mathbf{x})=\frac{1}{Z_N(\beta)}e^{-\beta\mathcal{H}(\mathbf{x})},\tag{1.25}$$

其中归一化常数 $Z_N(\beta)$ 称为配分函数。注意，配分函数与能量的矩生成函数密切相关。从概率角度看，构型 $\mathbf{x}\in\mathcal{X}^N$ 只是来自 Boltzmann–Gibbs 分布的随机样本，而宏观量可视为系综上的统计量。物理学家常用括号 $\langle\cdot\rangle_\beta$ 表示关于 Boltzmann–Gibbs 分布的平均，并称其为热平均。现在定义本讲义最重要的量：自由能密度，

$$-\beta f_N(\beta)=\frac{1}{N}\log Z_N(\beta).\tag{1.26}$$

注意，由于 Hamiltonian 通常是广延的 $\mathcal{H}=O(N)$，自由熵（配分和的对数）也是广延的，因此其密度是强度量。它与能量的累积量生成函数密切相关。正因如此，也如引言所讨论的，我们可以从自由熵获得系统许多重要的宏观性质。物理学家经常感兴趣的两个宏观量是能量密度与熵密度：

$$e_N(\beta)=\left\langle\frac{1}{N}\mathcal{H}(\mathbf{x})\right\rangle_\beta=\partial_\beta\big(\beta f_N(\beta)\big),\qquad\qquad s_N(\beta)=\beta^2\partial_\beta f_N(\beta),\tag{1.27}$$

它们满足有用关系

$$f_N(\beta)=e_N(\beta)-\frac{1}{\beta}s_N(\beta).\tag{1.28}$$

附录 1.B：相变入门

统计物理学家的主要目标之一是刻画系统的不同相。相可以宽泛地定义为模型参数空间中共享共同宏观性质的区域。例如，第 1 节研究的 Curie–Weiss 模型由参数 $(\beta, h) \in \mathbb{R}_+ \times \mathbb{R}$ 定义，我们在热力学极限中识别出了两个相：没有净系统磁化的顺磁相，以及具有净系统磁化的铁磁相。表征系统所处相的宏观量（在此为净磁化强度）称为系统的序参量。在第 16 章，我们将研究一个压缩感知模型，即重建被噪声污染的压缩稀疏信号的问题。该系统的参数为稀疏度（非零元素密度）$\rho \in [0, 1]$ 和噪声水平 $\Delta \in \mathbb{R}_+$。我们将识别出三个相：其中重建分别容易、困难或不可能。在这个例子中，序参量是估计量与信号之间的相关性。虽然这里研究的所有例子都有明确的序参量，但识别序参量并不总是容易的，它也不一定唯一。例如，在压缩感知例子中，也可以选择均方误差作为序参量。

当系统通过改变某个参数（如温度）而改变相时，我们称系统经历相变，并把分隔两个相的边界（位于参数空间中）称为相边界。在物理学中，我们通常用相图概括系统各相的信息，相图只是参数空间中相边界的图示。图 1.B.1 给出了物理学中两个著名相图的例子。 相变在物理上

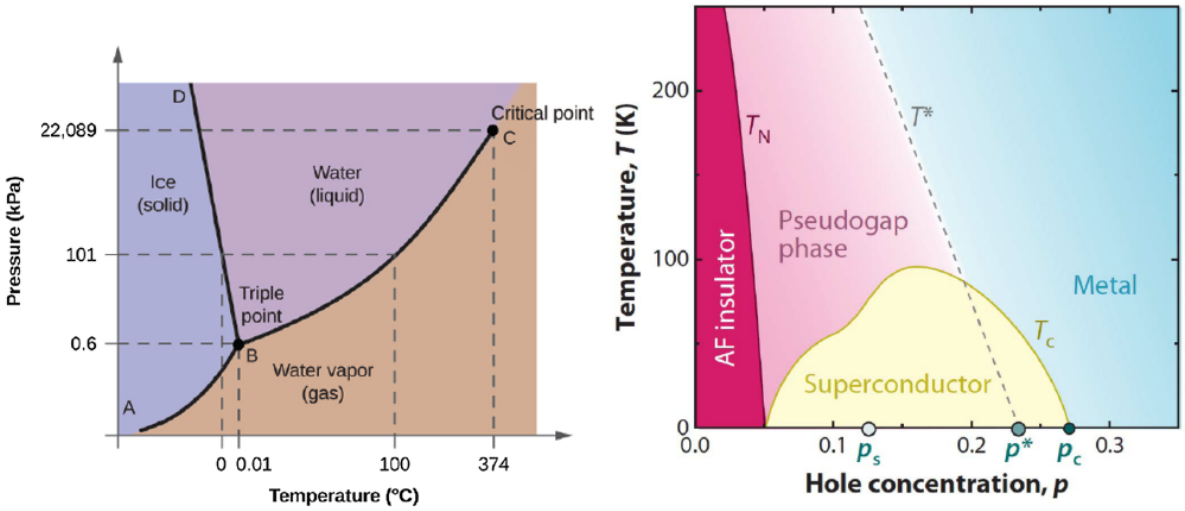


图 1.B.1: 水（左）和铜氧化物（右）的相图，分别来自 Taillefer（2010）和 Schwarz 等（2020）。左图横轴为温度、纵轴为压强；右图横轴为空穴浓度、纵轴为温度。

表现为系统行为的宏观变化（想一想水开始沸腾时发生了什么）。因此，读过第 1 节与附录 1.A 的讨论后，读者不应对相变可由自由能刻画和分类这一事实感到惊讶。实际上，根据自由能的解析性质对相变分类可以追溯到 Paul Ehrenfest 1933 年的工作（历史回顾见 Jaeger，1998）。此时，倾向数学的读者可能提出异议：式 (1.26) 的自由能是模型参数的解析函数，那么它如何在各相之间改变行为？事实上，对于有限 N，自由能是模型参数的解析函数。然而，解析函数序列的极限不一定解析，在热力学极限下自由能可以发展出奇异性。研究极限自由能的奇异行为是 Ehrenfest 相变分类的关键。两种最常见的相变是：

一级相变： 一级相变的特征是极限自由能对某个模型参数的一阶导数不连续。最常见的例子是在固定压强下改变温度时，水由液态转为气态（煮意大利面时所做的事情），见图 1.B.1 左图。在此例中，自由能对温度的导数，也称为熵，在相边界处发生不连续跳跃。

二级相变： 二级相变的特征是极限自由能对某个模型参数的二阶导数不连续。因此，在二级相变中，自由能本身及其一阶导数连续。注意，自由能的二阶导数通常与磁化率等响应函数相关。也许二级相变最著名的例子是某些金属随温度变化发生自发磁化，即铁磁相变。

虽然较少使用，我们也可以用极限自由能的第 n 阶导数不连续来定义 n 级相变。相变级数与丰富的现象学相关；为了具体起见，现在用我们最喜欢的模型——描述铁磁性的 Curie–Weiss 模型——来讨论。

Curie–Weiss 模型中的相变。 回忆第 1 节已经计算了 Curie–Weiss 模型自由能密度的热力学极限：

$$\begin{aligned} -\beta f_\beta &= \lim_{N\to\infty} \frac{1}{N} \log Z_N = \max_{m\in[-1,1]} \phi(m), \\ \phi(m) &= \frac{\beta}{2} m^2 + \beta h m + H(m), \\ H(m) &= -\frac{1+m}{2} \log \frac{1+m}{2} - \frac{1-m}{2} \log \frac{1-m}{2}. \end{aligned}$$

如前所示，上述最小化问题的解参数 m^* 给出系统的序参量，即平衡时的净磁化强度：

$$m^* = \operatorname{argmax}_{m\in[-1,1]} \phi(m) = -\partial_h f(\beta, h) = \langle \bar{S} \rangle_\beta. \tag{1.29}$$

特别地，极限平均能量和熵密度由下式给出：

$$e(\beta, h) = \partial_\beta \big(\beta f(\beta, h)\big) = -m^* \left(\frac{m^*}{2} + h \right), \qquad s(\beta, h) = \beta^2 \partial_\beta f(\beta, h) = H(m^*). \tag{1.30}$$

特别注意，熵密度只通过磁化强度 $m^* = m^*(\beta, h)$ 间接依赖模型参数 (β, h)。势函数 $\phi(m)$ 是 m 和参数 (β, h) 的解析函数。然而，由于对 m 的优化，自由能密度作为 (β, h) 的函数可以出现非解析行为，标志着相变的存在。现在回顾这些相变。

零外场与二级相变。 注意，分解 $f = e - \beta s$（见式 (1.27)）明确表明自由能是两个抛物线之间的竞争：能量（凸）和熵（凹）。在零外场 $h = 0$ 时，势是磁化强度的对称函数 $\phi(-m) = \phi(m)$。高温 $\beta \to 0^+$ 时，占主导的是熵，它在 $m^* = 0$ 处有唯一的全局最小值（见图 1.1）：这是系统没有净磁化的顺磁相。在临界温度 $\beta_c = 1$ 时，$m = 0$ 变为系统的一个最大值，并连续出现两个全局最小值（具有相同自由能），见图 1.4。这标志着系统转变为由净磁化 $|m^*| > 0$ 定义的铁磁相。注意，自由能对 β 的一阶导数（与熵成正比）在相变处保持连续。然而，我们发现自由能的二阶导数不连续，表明这是二级相变。这一相变对应于系统在宏观尺度上的统计行为发生显著变化：$\beta < 1$ 时从 Boltzmann–Gibbs 分布抽取的典型构型没有净磁化 $m^* = \langle \bar{S} \rangle_\beta \approx 0$（无序相）；$\beta > 1$ 时典型构型有净磁化 $|m^*| = |\langle \bar{S} \rangle_\beta| > 0$（有序相）。这是物理学中自发对称性破缺这一重要概念的一个例子：虽然系统 Hamiltonian 在 $\mathbb{Z}_2$ 对称变换 $\bar{S} \to -\bar{S}$ 下不变，但当 $\beta > 1$ 时，从 Gibbs–Boltzmann 分布中抽取的典型样本 $\mathbf{S} \sim \mathbb{P}_{N,\beta}$ 在宏观层面破坏了这一对称性。

二级相变具有丰富现象学。由于相变是二级的（即一阶导数连续），可通过研究自由能势在 $m = 0$ 附近的展开获得临界温度：

$$\phi(m) \underset{m\to 0}{=} \log 2 + \frac{m^2}{2}(\beta - 1) + O(m^3),$$

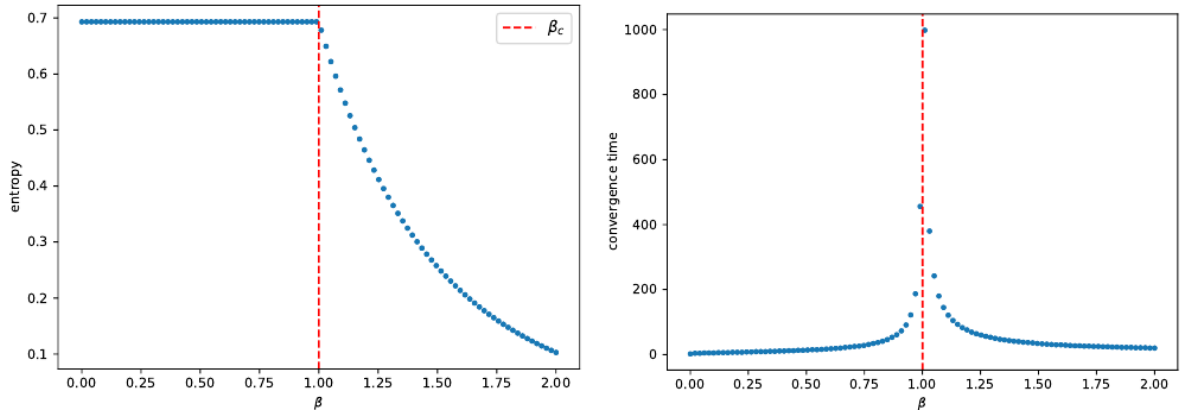


图 1.B.2: （左）零外场 $h = 0$ 时，熵随逆温度 β 的变化。熵是温度的连续函数，但在临界点 $\beta_c = 1$ 有尖点，表明其导数（与自由能的二阶导数成正比）不连续。（右）零外场 $h = 0$ 时鞍点方程的收敛时间随逆温度 β 的变化。注意二级临界点 $\beta_c = 1$ 附近的临界慢化。

这给出二阶导数变号之处的临界值 $\beta_c = 1$（$m = 0$ 从最小值变为最大值）。以鞍点方程 $m = \tanh(\beta m)$ 的角度看也很有用。$m = 0$ 始终是该方程不动点，说明它始终是自由能势的极值点。从这一角度看，临界温度 $\beta_c = 1$ 对应这一不动点稳定性的改变。将鞍点方程视为离散动力系统 $m_{t+1} = f(m_t)$，可通过查看更新函数 $f : [-1, 1] \to [-1, 1]$ 在不动点 $m = 0$ 附近的 Jacobian 来确定其稳定性：

$$f(x) = \tanh(\beta x) \underset{m\to 0}{=} \beta x + O(m^3). \tag{1.31}$$

$\beta < 1$ 时，不动点是稳定的（动力学的吸引子 / 汇）；$\beta > 1$ 时，它变为不稳定的（排斥子 / 源）。这意味着，在转变点附近 $\beta \approx 1^+$，从接近零但不恰好为零的初值 $m_{t=0} = \epsilon \ll 1$ 迭代鞍点方程，需要很长时间才能收敛到非零磁化 $m > 0$；越接近转变点，时间越发散。这一现象在物理学中称为临界慢化，连同自由能展开与方程稳定性分析，为刻画二级临界点提供了另一种方式。图 1.B.2 右图给出了示意。

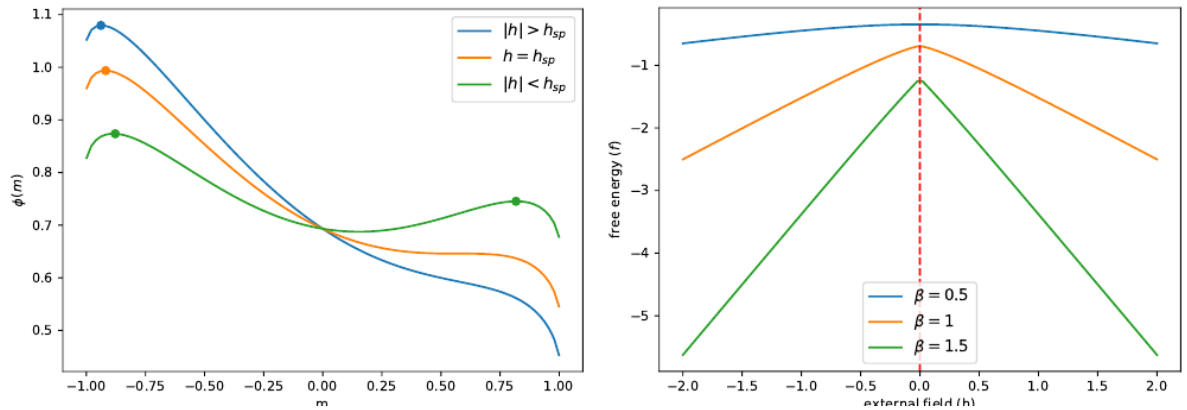


图 1.B.3: （左）固定逆温度 $\beta = 1.5$、改变外场 $h < 0$ 时自由能势 $\phi(m)$ 随 m 的变化。注意，当 $|h| > h_{\text{sp}}$ 时，自由能势有一个局部最大值，它在旋节线相变 $h = h_{\text{sp}}$ 处消失。（右）不同温度下自由能随外场 h 的变化。注意 $h = 0$ 处的非解析尖点。

有限外场与一级相变。 打开外磁场 $h \neq 0$ 可以显著改变上述讨论。首先注意，Hamiltonian 失去 $\mathbb{Z}_2$ 对称性：这在物理学中称为显式对称性破缺。在高温 $\beta \to 0^+$ 下，自由能势是凸的，在与外场对齐的 $m = h$ 处有唯一最小值。当温度降低、进入先前的铁磁相（$\beta > 1$）时，有两种可能行为。对于较小的 h，外场的效果仅是破坏先前两个全局最小值之间的对称性，使符号相反者变为局部最小值，见图 1.B.3 左图。在这种情况下，尽管平衡自由能由势的现在唯一的全局最小值给出，局部最小值的存在对动力学仍有重要影响。事实上，如果在与局部最小值对应的磁化强度附近初始化鞍点方程，它将收敛到这一局部最小值，因为这同时也是相应动力系统的稳定不动点，见图 1.B.4 左图。这一现象在物理学中称为亚稳性。注意，亚稳性这个名称可能产生误导，因为在热力学极限 $N \to \infty$ 下，亚稳态是自由能势的稳定不动点。然而，对于有限系统大小 N，系统会在量级 $t = O(e^N)$ 的时间内经动力学达到平衡。亚稳性在推断问题的统计物理分析中将起主要作用，因为它与算法困难性密切相关。

随着外场 h 增大，两个最小值之间的自由能势差增大，最终在称为旋节线点的临界场 h_{sp} 处，局部最小值消失，使势再次变为凸的，见图 1.B.3 左图。旋节线点可从自由能势的表达式导出，为

$$h_{\mathrm{sp}}(\beta) = \pm\sqrt{\frac{1}{\beta}\left(1-\frac{1}{\beta}\right)} \mp \frac{1}{\beta}\tanh^{-1}\left(\sqrt{1-\frac{1}{\beta}}\right), \qquad \beta > 1.$$

由此讨论显然可见，当 $\beta > 1$ 时，磁化强度（即自由熵对 h 的导数）在 $h = 0$ 处不连续，因为

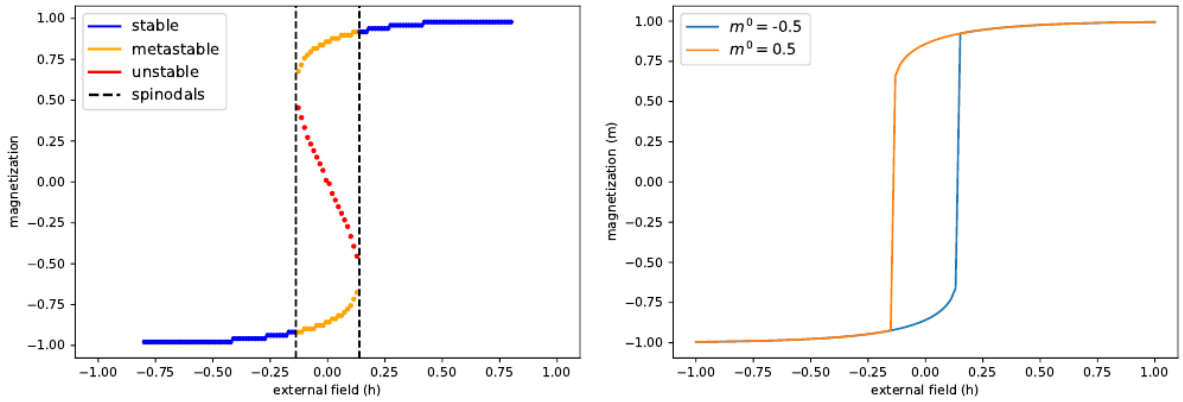


图 1.B.4: （左）固定逆温度 $\beta = 1.5$ 时，磁化强度随外场变化的稳定、亚稳与不稳定分支。（右）固定 $\beta = 1.5$，从不同初值 $m_{t=0}$ 迭代鞍点方程得到的磁化强度随外场 h 的变化。注意滞后回线：磁化强度从负值不连续跳到正值的点取决于系统的初态。

$h \neq 0$ 时磁化非零，而 $h = 0$ 时我们处于顺磁相 $h = 0$。这是系统关于外场 h 的一级相变，见图 1.B.3 右图。注意，由于亚稳性，在区域 $|h| < |h_{\mathrm{sp}}|$ 内，系统的磁化强度将依赖初始制备状态。这种初始状态的记忆在物理学中称为滞后，见图 1.B.4 右图。

附录 1.C：空腔法的严格版本

正如现在将要展示的，本章正文介绍的空腔法也可以完全严格地进行。不倾向数学的读者可以跳过本附录，尽管看看如何精确地完成这些论证总是有趣的。事实上，本节是后续章节的良好训练：尽管使用完全相同的技术，后续章节的严格证明会更加复杂。

首先，我们希望证明随着 N 增大，磁化强度以及许多其他可观测量确实收敛到固定值。这通过以下引理完成：如果 $\bar{S}$ 确实集中，那么任意可观测量也会集中。

引理 5. *对于任意有界可观测量 $O(\{S\}_N)$，存在常数 $C = \|O(\cdot)\|_\infty$，使得*

$$\big|\langle O(\mathbf{S})\rangle_{N+1,\beta'} - \langle O(\mathbf{S})\rangle_{N,\beta}\big| \le C\beta \sinh(\beta h + \beta)\sqrt{\mathrm{Var}_{N,\beta}(\bar{S})}. \tag{1.32}$$

译注（原文疑点）： 式 (1.32) 按原文保留，但在所述的一般范围内不能直接成立：若 $\beta > 0$ 且 $h < -1$，则右侧的 $\sinh[\beta(1+h)]$ 为负；对于有限温度下方差为正且 $C > 0$ 的情形，右侧严格为负，而左侧绝对值非负。下文证明中从 $\cosh \ge 1$ 去分母时也需考虑分子符号；$\bar{S} + h$ 与 $\bar{S} + \beta h$ 的混用、Jensen 不等式后的方差估计亦需核查。这里不据此替作者修正引理或断言后续结论错误；完整问题见工程问题记录。

证明. 证明如下。首先直接计算

$$\langle O(\mathbf{S})\rangle_{N+1,\beta'} = \frac{\langle O(\mathbf{S})\cosh(\beta(\bar{S}+h))\rangle_{N,\beta}}{\langle \cosh(\beta(\bar{S}+h))\rangle_{N,\beta}}.$$

因此有

$$\begin{aligned}
&\langle O(\mathbf{S})\rangle_{N+1,\beta'} - \langle O(\mathbf{S})\rangle_{N,\beta} \\
&= \frac{\langle O(\mathbf{S})\cosh(\beta(\bar{S}+h))\rangle_{N,\beta} - \langle O(\mathbf{S})\rangle_{N,\beta}\langle \cosh(\beta(\bar{S}+h))\rangle_{N,\beta}}{\langle \cosh(\beta(\bar{S}+h))\rangle_{N,\beta}} \\
&\le \langle O(\mathbf{S})\cosh(\beta(\bar{S}+\beta h))\rangle_{N,\beta} - \langle O(\mathbf{S})\rangle_{N,\beta}\langle \cosh(\beta(\bar{S}+h))\rangle_{N,\beta} \\
&= \mathrm{COV}_{N,\beta}\big[O(\mathbf{S}), \cosh(\beta(\bar{S}+\beta h))\big],
\end{aligned}$$

其中使用了 $\cosh x \ge 1$。遇到协方差时，应当总是尝试使用 Cauchy–Schwarz 公式 $\mathrm{Cov}^2(X,Y) < \mathrm{Var}(X)\,\mathrm{Var}(Y)$。在本例中，这导出

$$\big(\langle O(\mathbf{S})\rangle_{N+1,\beta'} - \langle O(\mathbf{S})\rangle_{N,\beta}\big)^2 \le \mathrm{Var}(O(\mathbf{S}))\,\mathrm{Var}\big(\cosh(\beta(\bar{S}+h))\big). \tag{1.33}$$

最后注意，$\cosh(\beta(\bar{S}+h))$ 作为变量 $\bar{S}$ 的函数是凸的 Lipschitz 函数，常数为 $\beta\sinh(\beta(1+h))$（因为 $\bar{S}$ 以 1 为界）。因此，依次应用 Jensen 不等式和 Lipschitz 不等式，得到

$$\begin{aligned}
&\cosh(\beta(\bar{S}+h)) - \langle \cosh(\beta(\bar{S}+h))\rangle \\
&\le \cosh(\beta(\bar{S}+h)) - \cosh(\beta(\langle \bar{S}\rangle + h)) \\
&\le \beta\sinh(\beta(1+h))(\bar{S} - \langle \bar{S}\rangle),
\end{aligned}$$

因此

$$\big\langle \cosh(\beta(\bar{S}+h)) - \langle \cosh(\beta(\bar{S}+h))\rangle\big\rangle^2 \le \beta^2 \sinh^2(\beta(1+h))\,\mathrm{Var}(\langle \bar{S}\rangle).$$

将这一关系代入式 (1.33) 即完成证明。 □

现在可以证明主要论点并得到平均场方程：

定理 5. *存在常数 $C(\beta, h)$，使得*

$$\big|\langle S_i\rangle_{N,\beta} - \tanh\beta\big(h + \langle \bar{S}\rangle_{N,\beta}\big)\big| \le C(\beta,h)\sqrt{\mathrm{Var}(\bar{S})}.$$

证明. 直接计算可得

$$\langle S_i\rangle_{N+1,\beta'} = \langle S_0\rangle_{N+1,\beta'} = \frac{\langle\sinh(\beta(\bar S + h))\rangle_{N,\beta}}{\langle\cosh(\beta(\bar S + h))\rangle_{N,\beta}}.$$

再次使用 Jensen 不等式及 cosh 和 sinh 的 Lipschitz 性，可得分式两项分别集中：

$$\big|\langle\sinh(\beta(\bar S + h))\rangle - \sinh(\beta(\langle\bar S\rangle + h))\big| \le \beta\cosh(\beta(1+h))\sqrt{\mathrm{Var}(\bar S)},$$
$$\big|\langle\cosh(\beta(\bar S + h))\rangle - \cosh(\beta(\langle\bar S\rangle + h))\big| \le \beta\sinh(\beta(1+h))\sqrt{\mathrm{Var}(\bar S)}.$$

结合不等式 $|a_1/b_1 - a_2/b_2| \le (a_1-a_2)/b_1 + a_2|b_1-b_2|/(b_1b_2)$，并使用 $a_i \ge 0$ 和 $b_i \ge \max(1, a_i)$，得到

$$\big|\langle S_i\rangle_{N+1,\beta'} - \tanh\beta\big(h + \langle\bar S\rangle_{N,\beta}\big)\big| \le C(\beta,h)\sqrt{\mathrm{Var}(\bar S)}.$$

再使用引理 5 即完成证明。 □

为了得到平均场方程，剩下要做的就是证明磁化强度的方差在相变 / 相共存线之外趋于零。这并不完全容易做到，但使用所谓的涨落耗散方法，我们可以容易地证明它在 (β, h) 平面上几乎处处成立：

引理 6 (方差界)**.** 对于任意 β 及磁场的两个值 h_1, h_2，有

$$\int_{h_1}^{h_2} \mathrm{Var}(\bar S)_{\beta,N,h}\, dh \le \frac{2}{\beta N},$$

因此对几乎所有 h，$\mathrm{Var}(\bar S)_{\beta,N,h} \le 2/N$。

译注（原文疑点）： 上式的 h 积分界本身并不直接蕴含同一有限 N 下关于 h 的几乎处处逐点上界；其后的逐点及极限结论需要额外论证。原陈述和证明仍按原文保留。

证明. 证明首先注意到 $\langle\bar S\rangle_{\beta,N} = \frac{\partial}{\partial(\beta h)}\Phi_N(\beta,h)$，而直接计算得

$$N\,\mathrm{Var}(\bar S)_{\beta,N,h} = \frac{\partial^2}{\partial(\beta h)^2}\Phi_N(\beta,h) = \frac{\partial}{\partial(\beta h)}\langle\bar S\rangle_{\beta,N}.$$

因此

$$N\int_{\beta h_1}^{\beta h_2} \mathrm{Var}(\bar S)_{\beta,N,h}\, d(\beta h) = \langle\bar S\rangle_{\beta,N,h_2} - \langle\bar S\rangle_{\beta,N,h_1} \le 2.$$

□

我们还可以用一种对于更复杂问题也非常有用的技术证明自由熵公式：

定理 6 (用空腔法求自由熵)**.**

$$\Phi(\beta,h) = \max_m \tilde\phi(m;\beta,h).$$

证明. 写出看似平凡的等式

$$\begin{aligned}\phi_N(\beta,h) &= \frac{1}{N}\log Z_N = \frac{1}{N}\log\left(\frac{Z_N}{Z_{N-1}}Z_{N-1}\right)\\ &= \frac{1}{N}\log\left(\frac{Z_N}{Z_{N-1}}\frac{Z_{N-1}}{Z_{N-2}}\cdots\frac{Z_1}{1}\right) = \frac{1}{N}\sum_{n=0}^{N-1}A_n(\beta,h), \qquad A_N(\beta,h) =: \log\frac{Z_{N+1}}{Z_N}.\end{aligned}$$

由 Stolz–Cesàro 定理，如果 A_n 收敛到 A，那么 $\Phi_N(\beta,h)$ 也收敛到 A。利用式 (1.21) 写成

$$A_N(\beta,h) =: \log\frac{Z_{N+1}}{Z_N} = \log\left\langle e^{-\frac{\beta}{2}\bar{S}^2}\,2\cosh\bigl(\beta(\bar{S}+h)\bigr)\right\rangle_{N,\beta} + o(1).$$

于是根据引理 5 和引理 6，对于任意 $\beta>0$ 和几乎所有 h，得到

$$\lim_{N\to\infty}A_N(\beta,h) = -\beta\frac{(m^*)^2}{2} + \log 2\cosh\bigl(\beta(m^*+h)\bigr),$$

其中 $m^* = \langle\bar{S}\rangle$。因此，对几乎所有外场，依照式 (1.21)，自由熵由式 (1.21) 的某个极值点 m^* 给出：

$$\Phi(\beta,h) = \tilde{\phi}(\langle\bar{S}\rangle).$$

剩下只需证明，如果有多个极值点，正确的极值是最大值。注意到 $\tilde{\phi}(m^*)=\phi(m^*)$，且通过 Gibbs 变分方法（定理 4）我们已证明对所有 m 有 $\Phi\geq\phi(m)$，即可说明它必然是最大值。由于熵对任意 N 均关于 h Lipschitz 连续（其导数是有界的磁化强度），其极限连续；因此如果自由熵几乎处处由 $\phi(m)$ 的最大值给出，那么它处处都成立。 □

2 一个简单例子：随机场 Ising 模型

让我们从最开头开始。这是个开始的好地方。

《音乐之声》，1965

让我们转向一个更有挑战性的例子。我们继续考虑一个由 N 个自旋 $s_i\in\{\pm1\}$ 组成的系统，其 Hamiltonian 为

$$\mathcal{H}_N(\mathbf{s},\mathbf{h}) = -\frac{N}{2}\left(\sum_i\frac{s_i}{N}\right)^2 - \sum_i h_i s_i,$$

但现在附加场 $\mathbf{h}$ 一经选定便固定不变。我们选择 $h_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\Delta)$。

这是 Ising 模型的一个简单变体，但现在我们有新的随机场 $\mathbf{h}$，这使问题稍微复杂了一些。因此，它称为随机场 Ising 模型，简称 RFIM。我们可以提出许多问题。例如，使能量最小的自旋赋值是什么？这是一个非平凡问题，因为这里存在竞争：使所有变量沿同一方向排列，与使它们沿局部随机场方向排列。该赋值的能量是多少？如果为 $\mathbf{h}$ 抽取另一个随机值，能量会有很大不同吗？我们如何在实践中找到这样的赋值？使用什么算法？

2.1 自平均与集中

我们将关注该系统在大 N 极限下的行为。如何处理随机变量？无序系统统计力学的整个领域及其在优化与统计中的应用，都建立在自平均的思想之上：即在系统大小极限 $N \to \infty$（数学家称其为渐近极限，物理学家称其为“热力学”极限）下，$\mathbf{h}$ 的具体实现并不重要。这是一个强大的思想，它使我们能够对所有 $\mathbf{h}$ 取平均。

让我们看看如何严格证明这一点。首先提醒：配分和 Z_N 随 N 指数增长，因此我们预期它围绕均值的涨落也会很大。幸运的是，如前所述，我们关注的是 $\log Z_N(\mathbf{h})/N$，希望它在 $N \to \infty$ 时收敛到 $O(1)$ 的常数值。量 $\log Z_N(\mathbf{h})/N$ 是随机的，它依赖 $\mathbf{h}$ 的取值，但我们可以预期 $\log Z_N(\mathbf{h})/N$ 的典型值接近其均值。足够大的系统接近其均值这一概念，在统计物理中称为“自平均”；在概率论中，这是测度集中的一种现象。

事实上，对于随机场 Ising 模型，我们可以证明：当 N 很大时，自由熵集中在其均值附近。

定理 7 (自平均)**.** *设 $\Phi_N(\mathbf{h},\beta) =: \log Z_N(\beta,\mathbf{h})/N$ 为 RFIM 的自由熵密度，则*

$$\mathrm{Var}[\Phi_N(\mathbf{h},\beta)] \le \frac{\Delta\beta^2}{N}.$$

证明. 该证明是非常有用的高斯 Poincaré 不等式（见习题 9 中的定理）的一个推论：假设 $f : \mathbb{R}^n \to \mathbb{R}$ 是光滑函数，且 X 服从多元高斯分布 $X \sim \mathcal{N}(0,\Gamma)$，其中 $\Gamma \in \mathbb{R}^{n\times n}$，则

$$\mathrm{Var}[f(X)] \le \mathbb{E}\big[\Gamma\nabla f(X)\cdot\nabla f(X)\big].$$

对于 RFIM，由于

$$\partial_{h_i}\Phi_N(\mathbf{h},\beta) = \frac{\beta}{N}\langle S_i\rangle,$$

我们发现

$$\nabla\Phi_N(\mathbf{h},\beta)\cdot\nabla\Phi_N(\mathbf{h},\beta) = \frac{\beta^2}{N}\sum_i \frac{\langle S_i\rangle^2}{N} \le \frac{\beta^2}{N},$$

而取 $\Gamma = \Delta I$（$\mathbf{h}$ 的协方差矩阵）的高斯 Poincaré 不等式给出最终结果。 □

因此，我们不再为每一个 $\mathbf{h}$ 的实现计算自由熵密度，而是转而计算对所有可能的 $\mathbf{h}$ 取期望，即定义

$$\Phi(\beta,\Delta) \triangleq \lim_{N\to\infty} \mathbb{E}_{\mathbf{h}}\Phi_N(\beta,\delta,\mathbf{h}) = \lim_{N\to\infty}\frac{1}{N}\mathbb{E}_{\mathbf{h}}[\log Z_N(\beta,\mathbf{h})].$$

自平均性质保证，当 N 很大时，$\mathbb{E}_{\mathbf{h}}[\log Z_N(\beta,\mathbf{h})]/N$ 接近 $[\log Z_N(\beta,\mathbf{h})]/N$。在概率论中，当方差趋于零时，人们说随机变量依概率收敛。因此这里我们已经证明，$\Phi_N(\beta,\mathbf{h},\Delta)$ 依概率收敛到 $\Phi(\beta,\Delta)$。事实上，我们还可以进一步证明，偏离超过方差的概率指数地小，因此即使在中等 N 值下我们也绝对安全。这使我们面临如何计算 $\Phi(\beta,\Delta)$ 的问题，因为它涉及对数的期望。

译注（原文疑点）： 方差趋于零保证随机变量与其自身均值之差依概率趋于零；要收敛到某个固定常数，还需均值收敛。原文“偏离超过方差的概率指数地小”未注明偏离阈值的尺度或额外条件；仅凭方差界并不能得到这一断言，例如方差为 $1/N$ 的高斯变量通常有 $N^{-1/2}$ 量级涨落。上述两处保留原文，待进一步核查。

2.2 副本方法

为了计算对数的平均值，统计物理中广泛使用了一种有力的启发式方法：副本方法。它由 Sam Edwards 爵士在 20 世纪 70 年代提出（他将其归功于 Marc Kac）。论证如下：假设 n 接近零，则

$$Z^n = e^{n\log Z} = 1 + n\log Z + o(n) \quad \Longrightarrow \quad \log Z = \lim_{n\to 0}\frac{Z^n - 1}{n}.$$

如果 Z 是随机变量，并且我们假设可以交换极限与期望（这绝非显然），就得到常被称为“副本技巧”的恒等式：

$$\mathbb{E}[\log Z] = \mathbb{E}\left[\lim_{n\to 0}\frac{Z^n - 1}{n}\right] = \lim_{n\to 0}\frac{\mathbb{E}[Z^n] - 1}{n}.$$

这就是副本方法的根源：我们把难以计算的 Z 的对数平均替换为 Z 的幂的平均。如果 n 是整数，我们可以期望确实能够计算 Z^n 的平均。然后可以“假装”有限 n 的计算对 $n \in \mathbb{R}$ 也有效（这同样是非平凡的一步），将结果从自然数解析延拓到实数，再令 $n \to 0$。虽然这听上去像杂技，显然不像严格数学，但令人惊讶的是，只要遵循过去几十年物理学家沿 Giorgio Parisi 与 Marc Mézard 的足迹提出的准则，它似乎运作得相当好。实际上，在可以将其与严格计算比较的情形中，这一方法似乎总是给出正确结果。如今人们对副本方法给出的结果有很深的信任。

我们将在后面回到严格数学能够说明什么的问题。首先让我们使用上一章的“场论”工具箱，详细看看这一方法如何用于计算随机场 Ising 模型的 $\Phi(\beta, \Delta)$。

2.2.1 计算副本配分函数

设 n 为副本数，$\alpha = 1, \dots, n$ 为副本指标（这些是副本文献中的传统记号），则

$$Z^n = \sum_{s^{(1)}}\sum_{s^{(2)}}\cdots\sum_{s^{(n)}}\exp\left\{\sum_{\alpha=1}^{n}\beta\left[\frac{N}{2}\left(\sum_i \frac{s_i^{(\alpha)}}{N}\right)^2 + \sum_i h_i s_i^{(\alpha)}\right]\right\}.$$

现在对随机场取平均，并像处理 Curie–Weiss 模型时一样固定磁化强度；这一次对 $\alpha = 1, \dots, n$ 标记的每一个“副本”都这样做：

$$\begin{aligned}
\mathbb{E}_{\mathbf{h}}[Z^n] &= \mathbb{E}_{\mathbf{h}}\left[\sum_{\{s^{(\alpha)}\}_{\alpha=1}^n} e^{\beta\frac{N}{2}\sum_{\alpha=1}^n(\sum_i s_i^{(\alpha)}/N)^2 + \beta\sum_{\alpha=1}^n\sum_i h_i s_i^{(\alpha)}}\right] \\
&\overset{(a)}{=} N^n\mathbb{E}_{\mathbf{h}}\left[\sum_{\{s^{(\alpha)}\}_\alpha}\int\prod_\alpha dm_\alpha\,\delta\left(\sum_i s_i^{(\alpha)} - Nm_\alpha\right)e^{\beta\frac{N}{2}\sum_\alpha m_\alpha^2 + \beta\sum_\alpha\sum_i h_i s_i^{(\alpha)}}\right] \\
&\overset{(b)}{=} (2i\pi N)^n\mathbb{E}_{\mathbf{h}}\left[\sum_{\{s^{(\alpha)}\}_\alpha}\int\prod_\alpha dm_\alpha d\widehat{m}_\alpha\, e^{\sum_\alpha\widehat{m}_\alpha[\sum_i s_i^{(\alpha)} - Nm_\alpha]}e^{\beta\frac{N}{2}\sum_\alpha m_\alpha^2 + \beta\sum_\alpha\sum_i h_i s_i^{(\alpha)}}\right] \\
&\propto \int\prod_\alpha dm_\alpha d\widehat{m}_\alpha\, e^{\beta\frac{N}{2}\sum_\alpha m_\alpha^2 - N\sum_\alpha\widehat{m}_\alpha m_\alpha}\mathbb{E}_{\mathbf{h}}\left[\sum_{\{s^{(\alpha)}\}_\alpha} e^{\sum_\alpha\widehat{m}_\alpha\sum_i s_i^{(\alpha)} + \beta\sum_\alpha\sum_i h_i s_i^{(\alpha)}}\right].
\end{aligned}$$

其中，(a) 按磁化强度拆分求和；(b) 对 Dirac delta 函数作 Fourier 变换，然后换元 $\widehat{m}_\alpha = 2\pi i\lambda_\alpha$。接着我们选择忽略积分前无关的系数。于是

$$\mathbb{E}_{\mathbf{h}}[Z^n] \propto \int\prod_\alpha dm_\alpha d\widehat{m}_\alpha\, e^{\beta\frac{N}{2}\sum_\alpha m_\alpha^2 - N\sum_\alpha\widehat{m}_\alpha m_\alpha}\mathbb{E}_{\mathbf{h}}\left[\sum_{\{s^{(\alpha)}\}_\alpha}\prod_\alpha\prod_i e^{\widehat{m}_\alpha s_i^{(\alpha)} + \beta h_i s_i^{(\alpha)}}\right]$$

$$
\begin{aligned}
&\overset{(c)}{\propto} \int \prod_{\alpha} dm_\alpha d\widehat{m}_\alpha \, e^{\beta \frac{N}{2} \sum_\alpha m_\alpha^2 - N \sum_\alpha \widehat{m}_\alpha m_\alpha} \mathbb{E}_{\mathbf{h}} \left[\prod_i \prod_\alpha \sum_{s_i^{(\alpha)} = \pm 1} e^{\widehat{m}_\alpha s_i^{(\alpha)} + \beta h_i s_i^{(\alpha)}} \right] \\
&\overset{(d)}{\propto} \int \prod_{\alpha} dm_\alpha d\widehat{m}_\alpha \, e^{\beta \frac{N}{2} \sum_\alpha m_\alpha^2 - N \sum_\alpha \widehat{m}_\alpha m_\alpha} \left\{ \mathbb{E}_h \left[\prod_\alpha 2\cosh(\beta h + \widehat{m}_\alpha) \right] \right\}^N \\
&= \int \prod_{\alpha} dm_\alpha d\widehat{m}_\alpha \, \exp\left\{ N \left[\frac{\beta}{2} \sum_\alpha m_\alpha^2 - \sum_\alpha \widehat{m}_\alpha m_\alpha + \log \mathbb{E}_h \left(\prod_\alpha 2\cosh(\beta h + \widehat{m}_\alpha) \right) \right] \right\}.
\end{aligned}
$$

其中 (c) 将乘积的和写为和的乘积；(d) 来自所有 h_i 独立同分布，因此对向量 $\mathbf{h}$ 的积分换成了对单个标量 h 的积分。我们再次完全去掉了组合求和，代价是引入积分。

2.2.2 副本对称假设

此时我们似乎得到了相当复杂的表达式：现在必须设法对所有的 $m_\alpha, \widehat{m}_\alpha$ 积分，再神奇地取 $n \to 0$ 极限。这些积分可视为对两个 n 维向量 $\mathbf{m}$ 和 $\widehat{\mathbf{m}}$ 的积分，即

$$
\int \prod_\alpha dm_\alpha d\widehat{m}_\alpha =: \int d\mathbf{m}\, d\widehat{\mathbf{m}}.
$$

从积分的结构看，我们应当预期鞍点法适用，从而对指数中的表达式关于这两个向量取极值。尽管这看上去是一个艰巨的任务（对所有可能的向量求最大值！），我们可以猜测极值处这些向量的形式。一个非常合理的假设称为副本对称（RS）假设，即在极值处所有副本等价，因此

$$
m_\alpha \equiv m, \qquad \widehat{m}_\alpha \equiv \widehat{m}, \qquad \forall \alpha.
$$

物理学家沿袭 19 世纪末和 20 世纪初德国科学巨匠的传统，称这种猜测为 Ansatz。采用副本对称假设后，看似巨大的怪物 $\mathbb{E}_{\mathbf{h}}[Z^n]$ 便化为较温和的形式：

$$
\mathbb{E}_{\mathbf{h}}[Z^n] =\propto \int dm\, d\widehat{m} \, \exp\left\{ N \left[\frac{\beta}{2} n m^2 - n \widehat{m} m + \log(\mathbb{E}_h[2^n \cosh^n(\beta h + \widehat{m})]) \right] \right\}.
$$

我们大大简化了问题，所求平均自由熵可以写作

$$
\begin{aligned}
\Phi(\beta, \Delta) &= \lim_{N\to\infty} \frac{1}{N} \mathbb{E}_{\mathbf{h}}[\log Z(\beta, \mathbf{h})] \\
&\overset{(a)}{=} \lim_{N\to\infty} \frac{1}{N} \lim_{n\to 0} \frac{\mathbb{E}_{\mathbf{h}}[(Z(\beta,\mathbf{h}))^n] - 1}{n} \\
&\overset{(b)}{=} \lim_{n\to 0} \frac{1}{n} \lim_{N\to\infty} \frac{\mathbb{E}_{\mathbf{h}}[(Z(\beta,\mathbf{h}))^n] - 1}{N} \\
&\overset{(c)}{=} \lim_{n\to 0} \frac{1}{n} \operatorname{Extr}_{m,\widehat{m}} \left[\frac{\beta}{2} n m^2 - n \widehat{m} m + \log(\mathbb{E}_h[2^n \cosh^n(\beta h + \widehat{m})]) \right],
\end{aligned}
$$

其中 (a) 直接应用副本技巧；(b) 非严格地交换了两个极限，这是副本方法中假设成立的；(c) 是鞍点法。副本计算已近完成，最后一步是消去剩余的 n。这可以通过再次使用副本技巧做到：

$$
\begin{aligned}
\Phi(\beta, \Delta) &\overset{(d)}{=} \lim_{n\to 0} \frac{1}{n} \operatorname{Extr}_{m,\widehat{m}} \left[\frac{\beta}{2} n m^2 - n \widehat{m} m + n \mathbb{E}_h[\log(2\cosh(\beta h + \widehat{m}))] \right] \\
&= \operatorname{Extr}_{m,\widehat{m}} \left[\frac{\beta}{2} m^2 - \widehat{m} m + \mathbb{E}_h[\log(2\cosh(\beta h + \widehat{m}))] \right],
\end{aligned}
$$

其中 (d) 使用了当 $n \to 0^+$ 时的技巧：

$$\mathbb{E}[X^n] = \mathbb{E}[e^{n \log X}] \approx \mathbb{E}[1 + n \log X] = 1 + n\mathbb{E}[\log X] \approx e^{n\mathbb{E}[\log X]},$$
$$\log(\mathbb{E}[X^n]) \approx \log(1 + n\mathbb{E}[\log X]) \approx n\mathbb{E}[\log X].$$

这种带有巫术色彩的副本魔法应当令人惊讶：本质上我们看到，当 $n \to 0$ 时，可以把期望推进函数内部！这已经暗示，要使其真正成立，我们需要随机变量的某种集中性质！无论如何，我们已经完成计算中的副本部分，成功将问题转回一个二维函数的极值问题，就像 Curie–Weiss 模型那样：

$$\Phi(\beta, \Delta) = \mathrm{extr}_{m,\widehat{m}} \left[\frac{\beta}{2} m^2 - \widehat{m} m + \mathbb{E}_h[\log(2\cosh(\beta h + \widehat{m}))] \right].$$

译注： 本节将 $N \to \infty$ 与 $n \to 0$ 的极限交换，并通过鞍点法从 $\mathbb{E}[Z^n]$ 推至 (c)；原文已将此过程称为非严格步骤。此外，对固定正 n，$\mathbb{E}[Z^n]$ 随 N 可呈指数增长，其线性除以 N 不足以直接得到相邻的鞍点指数；上述等式按原文保留，严谨论证及极限次序仍须另行核查。

2.2.3 计算鞍点：平均场方程

现在需要计算鞍点。我们有

$$\frac{\partial}{\partial m} \left[\frac{\beta}{2} m^2 - \widehat{m} m + \mathbb{E}_h[\log(2\cosh(\beta h + \widehat{m}))] \right] = \beta m - \widehat{m} \quad \Longrightarrow \quad \widehat{m} = \beta m.$$

将其代回，得到一个与 Curie–Weiss 模型的结果非常相似的公式。定义

$$\Phi_{\mathrm{RS}}(m, \beta, \Delta) \triangleq -\frac{\beta}{2} m^2 + \mathbb{E}_h[\log(2\cosh(\beta(h + m)))],$$

我们发现

$$\Phi(\beta, \Delta) = \mathrm{extr}_m \, \Phi_{\mathrm{RS}}(m) = \Phi_{\mathrm{RS}}(m^*), \tag{2.1}$$

其中 m^* 满足自洽平均场方程

$$m = \mathbb{E}_h[\tanh(\beta(h + m))] = \int dh \, \frac{e^{-h^2/(2\Delta)}}{\sqrt{2\pi\Delta}} \tanh(\beta(h + m)).$$

正如处理 Curie–Weiss 模型时那样，我们还可以计算给出固定 m 值下自由熵的大偏差函数。事实上，它同样是自平均的，因为我们可以加上一个指示函数，重复定理 7 的所有步骤。自由熵通过按正确次序求鞍点得到：首先关于 $\widehat{m}$ 求导，从而得到关于 $\widehat{m}^*$ 的隐式方程

$$m = \mathbb{E}_h[\tanh(\beta h + \widehat{m}^*)].$$

因此，副本对称方法预测

$$\mathbb{P}(\overline{S} = m) \asymp e^{N\Phi^{\mathrm{LD}}(\beta, \Delta, m)},$$

其中

$$\Phi^{\mathrm{LD}}(\beta, \Delta, m) = \mathrm{extr}_{\widehat{m}} \left[\frac{\beta}{2} m^2 - \widehat{m} m + \mathbb{E}_h[\log(2\cosh(\beta h + \widehat{m}))] \right],$$

而关于 $\widehat{m}$ 取极值要求它解出式 (2.2.3)。事实上容易检验，这恢复了上一章的大偏差函数。**译注：**原文上述 Φ^{LD} 是固定磁化强度的受限自由熵，概率的指数率还须减去总自由熵 $\Phi(\beta,\Delta)$。例如 $\beta=0, m=0$ 时，所写 $\Phi^{\mathrm{LD}}=\log 2$，原概率右端会随 N 增长而大于 1。原式保留，不能直接作为归一化概率；离散磁化点的概率与连续密度也须区分。源文所引 “(2.2.3)” 无对应公式编号，下文称式 (2.1) 为自洽方程时，实际指其后紧接的未编号方程。

图 2.2.1 展示了副本预测的结果，其中绘出了赋值的最小成本随随机场方差的变化。这是通过求解自洽方程 (2.1)，并对自由熵关于逆温度求导以计算平衡能量而得到的：

$$\mathbb{E}\langle e\rangle = -\partial_\beta \Phi(\beta,\Delta) = \frac{(m^*)^2}{2} - \mathbb{E}_h[(h+m^*)\tanh(\beta(h+m^*))], \tag{2.2}$$

然后取零温极限，得到

$$\mathbb{E}[e_{\min}] = \frac{(m^*)^2}{2} - \mathbb{E}_h[(h+m^*)\operatorname{sign}(h+m^*)]. \tag{2.3}$$

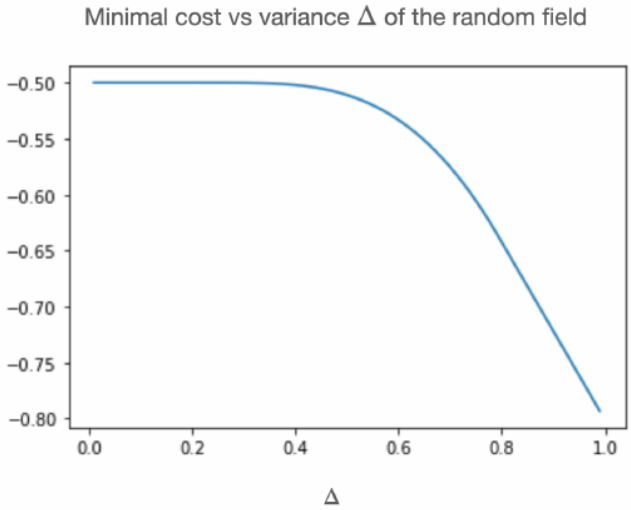


图 2.2.1: 随机场 Ising 模型的最小能量随方差 Δ 的变化。图中英文标题意为 “最小成本与随机场方差 Δ 的关系”。

2.3 使用插值技术的严格计算

鉴于上述计算颇像杂技，我们自然希望通过严格论证确认所得结果是精确的。为此，我们将使用 Francesco Guerra 引入的插值方法来证明副本方法的结果。

2.3.1 一个简单问题

首先从一个不同但更简单的问题出发。考虑哈密顿量为

$$\mathcal{H}_0(s,\mathbf{h};m) = -\sum_i s_i(h_i+m)$$

的系统。对应的配分函数和每个自旋的自由熵为

$$Z_0(\beta,\mathbf{h};m)=\sum_s e^{\beta\sum_i s_i(h_i+m)}=\prod_i\sum_{s_i=\pm1}e^{\beta s_i(h_i+m)}=\prod_i 2\cosh(\beta(h_i+m)),$$
$$\Phi_0(\beta,\Delta;m)=\mathbb{E}_{\mathbf{h}}\left[\frac{\log Z_0(\beta,\mathbf{h};m)}{N}\right]=\mathbb{E}_h[\log(2\cosh(\beta(h+m)))].$$

实际上，我们甚至可以在 $\overline{S}=s$ 的固定值下定义此配分函数，以研究大偏差：

$$Z_0(\beta,\mathbf{h};m,s)=\sum_s \mathbf{1}(\overline{S}=s)e^{\beta\sum_i s_i(h_i+m)}.$$

我们不知道如何直接计算，但可以使用 Gartner–Ellis 定理或 Legendre 变换，因为当 $N\to\infty$ 时，这等价于计算速率函数。于是写下

$$\widetilde{Z}_0(\beta,\mathbf{h};m,k)=\sum_s e^{\beta\sum_i s_i(h_i+m)+k\sum_i s_i},$$
$$\frac{1}{N}\widetilde{Z}_0(\beta,\mathbf{h};m,k)\to\mathbb{E}_h[\log(2\cosh(\beta(h+m)+k))].$$

译注：第二行照原文保留，但左侧的 $\widetilde{Z}_0$ 通常随 N 指数增长，而右侧是有限的对数平均；此处左侧是否遗漏 log 需要核查。

由 Gartner–Ellis 定理并令 $s=m$，得到

$$\begin{aligned}\Phi_0(\beta,m,\Delta)&=\lim_{N\to\infty}\frac{1}{N}\log Z_0(\beta,\mathbf{h};m,\overline{S}=m)\\&=\mathbb{E}_h[\log(2\cosh(\beta(h+m)+k^*))]-k^*m,\\m&=\mathbb{E}_h[\tanh(\beta(h+m)+k^*)].\end{aligned}$$

作简单换元 $k^*=\widehat{m}-\beta m$，便得到

$$\Phi_0(\beta,m,\Delta)=\operatorname{extr}_{\widehat{m}}\mathbb{E}_h[\log(2\cosh(\beta h+\widehat{m}))]-m\widehat{m}+\beta m^2.$$

我们现在得到的形式已经看起来非常接近副本预测！

2.3.2 Guerra 插值

Guerra 方法通过修改哈密顿量 $\mathcal{H}_0$，将其逐渐变成实际问题。具体方法是：在不同“时间” t 定义一族哈密顿量及对应配分函数：

$$\mathcal{H}_t(s,\mathbf{h};m)=-\sum_i s_i[h_i+m(1-t)]-t\frac{N}{2}\left(\sum_i\frac{s_i}{N}\right)^2,$$
$$Z_t(\beta,\mathbf{h};m)=\sum_s\mathbf{1}(\overline{S}=m)e^{-\beta\mathcal{H}_t(s,\mathbf{h};m)},\qquad\forall t\in(0,1].$$

容易验证，$t=0$ 时恢复上一段的模型，而 $t=1$ 时

$$\mathcal{H}_1(s,\mathbf{h};m)\equiv\mathcal{H}_{\mathrm{RFIM}}(s,\mathbf{h}),\qquad Z_1(\beta,\mathbf{h};m)\equiv Z_{\mathrm{RFIM}}(\beta,\mathbf{h},m),\qquad\forall m\in[-1:1].$$

我们从时间 0 的模型插值到时间 1，利用微积分基本定理写成

$$\begin{aligned}\Phi(\beta,m,\Delta) &= \lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\frac{\log Z_{\mathrm{RFIM}}(\beta,\mathbf{h})}{N}\right]\\ &= \lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\frac{\log Z_1(\beta,\mathbf{h};m)}{N}\right]\\ &= \lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\frac{\log Z_0(\beta,\mathbf{h};m)}{N}+\int_0^1 d\tau\,\frac{\partial}{\partial t}\frac{\log Z_t(\beta,\mathbf{h};m)}{N}\bigg|_{t=\tau}\right]\\ &= \Phi_0(m,\Delta,\beta)+\lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\int_0^1 d\tau\,\frac{\partial}{\partial t}\frac{\log Z_t(\beta,\mathbf{h};m)}{N}\bigg|_{t=\tau}\right].\end{aligned}$$

剩下的是计算额外的积分项。我们发现

$$\begin{aligned}\frac{\partial}{\partial t}\frac{\log Z_t(\beta,\mathbf{h};m)}{N} &= \frac{1}{N}\frac{1}{Z_t(\beta,\mathbf{h};m)}\frac{\partial}{\partial t}\sum_s \mathbf{1}(\overline{S}=m)e^{-\beta\mathcal{H}_t(s,\mathbf{h};m)}\\ &= \frac{1}{N}\frac{1}{Z_t(\beta,\mathbf{h};m)}\sum_s \mathbf{1}(\overline{S}=m)e^{-\beta\mathcal{H}_t(s,\mathbf{h};m)}(-\beta)\frac{\partial}{\partial t}\mathcal{H}_t(s,\mathbf{h};m)\\ &= \frac{\beta}{NZ_t(\beta,\mathbf{h};m)}\sum_s \mathbf{1}(\overline{S}=m)e^{-\beta\mathcal{H}_t(s,\mathbf{h};m)}\left[-m\sum_i s_i+\frac{N}{2}\left(\sum_i\frac{s_i}{N}\right)^2\right]\\ &= \beta\sum_s \underbrace{\frac{\mathbf{1}(\overline{S}=m)e^{-\beta\mathcal{H}_t(s,\mathbf{h};m)}}{Z_t(\beta,\mathbf{h};m)}}_{=P_{\beta,t,\mathbf{h},m}(s)}\left[-m\sum_i\frac{s_i}{N}+\frac{1}{2}\left(\sum_i\frac{s_i}{N}\right)^2\right]\\ &= \beta\left\{-m\left\langle\sum_i\frac{s_i}{N}\right\rangle_{\beta,t,\mathbf{h},m}+\frac{1}{2}\left\langle\left(\sum_i\frac{s_i}{N}\right)^2\right\rangle_{\beta,t,\mathbf{h},m}\right\}\\ &= \beta\left\{\frac{1}{2}\left\langle\left(m-\sum_i\frac{s_i}{N}\right)^2\right\rangle_{\beta,t,\mathbf{h},m}-\frac{m^2}{2}\right\}.\end{aligned}$$

代回后得到

$$\begin{aligned}\Phi(\beta,m,\Delta) &= \Phi_0(\beta,m,\Delta)+\lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\int_0^1 d\tau\,\beta\left\{\frac{1}{2}\left\langle\left(m-\sum_i\frac{s_i}{N}\right)^2\right\rangle_{\beta,\tau,\mathbf{h},m}-\frac{m^2}{2}\right\}\right]\\ &= \underbrace{\Phi_0(\beta,m,\Delta)-\frac{\beta m^2}{2}}_{=\Phi_{\mathrm{RS}}(m)}+\underbrace{\frac{\beta}{2}\lim_{N\to\infty}\mathbb{E}_{\mathbf{h}}\left[\int_0^1 d\tau\left\langle\left(m-\sum_i\frac{s_i}{N}\right)^2\right\rangle_{\beta,\tau,\mathbf{h},m}\right]}_{=0}\\ &= \mathrm{extr}_{\widehat{m}}\,\Phi_{\mathrm{RS}}(m,\widehat{m}),\qquad \forall m\in[-1:1],\end{aligned}$$

其中最后一项为零，是因为我们已将磁化强度限制为恰好等于 m。因此，我们成功证明了对所有 m 值成立的自由熵副本对称方程。更重要的是，我们看到了副本方法是可信赖的！

译注： 本小节按原文记号保留了固定磁化强度的 $Z_t(\beta,\mathbf{h};m)$、后面无显式 m 的 $Z_{\mathrm{RFIM}}(\beta,\mathbf{h})$，以及多个自由熵函数的记号。固定磁化强度配分函数与未限制的配分函数一般不同；有限 N 时 m 还必须取可实现的磁化值。原文把两者写成相等及其对全 m 结论的影响需要单独核查，不能仅凭上述推导认定无约束自由熵的严格结论。

文献说明。 关于物理学中随机场 Ising 模型，一篇很好的综述是 Nattermann (1998)。它在无序系统的发展中起到了基础性作用。副本方法由 Sam Edwards 引入，Edwards 将其归功于 Marc Kac（Edwards 等，2005）。在以 Parisi、Mézard 和 Virasoro 为首的一代物理学家的工作推动下，副本方法成为一种强大而多用途的工具（Mézard 等，1987b）。我们讨论的用于证明副本公式的插值技巧由 Guerra (2003) 首次提出。这里所用的固定磁化强度这一特殊技术受到 El Alaoui 和 Krzakala (2018) 的启发。高斯 Poincaré 等概率不等式是现代概率论与统计学理论的基础，Boucheron 等 (2013) 是一个很好的参考资料。这些集中不等式是统计物理模型所有严格数学处理方法的基石。

2.4 习题

习题 2.1：高斯 Poincaré 不等式与 Efron–Stein 不等式

为了证明高斯 Poincaré 不等式，我们首先需要证明适用范围很广的 Efron–Stein 不等式，它是概率论中许多重要结果的基础：

定理 8 (Efron–Stein)**.** 假设 $X_1, \dots, X_n$ 和 $X_1', \dots, X_n'$ 是独立随机变量，且对所有 i，X_i 与 X_i' 同分布。令 $X = (X_1, \dots, X_i, \dots, X_n)$，$X^{(i)} = (X_1, \dots, X_{i-1}, X_i', X_{i+1}, \dots, X_n)$。则对任意函数 $f : \mathbb{R}^n \to \mathbb{R}$，有

$$\operatorname{Var}(f(X)) \le \frac{1}{2} \sum_{i=1}^{n} \mathbb{E}[(f(X) - f(X^{(i)}))^2].$$

我们将通过考虑 X_i 和 X_i' 的混合系综上的平均，使用所谓 Lindeberg 技巧证明 Efron–Stein 不等式。首先定义随机向量 $X_{(i)}$：到第 i 个指标为止使用 X'，对更大的指标使用 X，即 $X_{(i)} = (X_1', \dots, X_{i-1}', X_i', X_{i+1}, \dots, X_n)$。特别地，$X_{(0)} = X$ 且 $X_{(n)} = X'$。

1. 证明（称为 Lindeberg 替换技巧）

$$\operatorname{Var}[f(X)] = \mathbb{E}[f(X)(f(X) - f(X'))] = \sum_{i=1}^{n} \mathbb{E}[f(X)(f(X_{(i-1)}) - f(X_{(i)}))].$$

2. 证明对所有 i，

$$\begin{aligned} \mathbb{E}[f(X)(f(X_{(i-1)}) - f(X_{(i)}))] &= \mathbb{E}[f(X^{(i)})(f(X_{(i)}) - f(X_{(i-1)}))] \\ &= \frac{1}{2}\mathbb{E}[(f(X) - f(X^{(i)}))(f(X_{(i-1)}) - f(X_{(i)}))]. \end{aligned}$$

3. 利用 Cauchy–Schwarz 不等式证明

$$\left|\mathbb{E}[f(X)(f(X_{(i-1)}) - f(X_{(i)}))]\right| \le \frac{1}{2}\mathbb{E}[(f(X) - f(X^{(i)}))^2],$$

并证明 Efron–Stein 定理。

有了 Efron–Stein 不等式，就可以证明高斯随机变量的 Poincaré 不等式。我们仅对单变量证明，读者可以将证明推广到多变量情形。设 X_i 为各以 1/2 的概率取 ± 1 的随机变量（称为 Rademacher 随机变量），定义

$$S_n = X_1 + X_2 + \cdots + X_n.$$

4. 使用 Efron–Stein 不等式证明

$$\operatorname{Var}\left[f\left(\frac{S_n}{\sqrt{n}}\right)\right] \le \frac{n}{4}\mathbb{E}\left[\left(f\left(\frac{S_{n-1}}{\sqrt{n}}+\frac{1}{\sqrt{n}}\right)-f\left(\frac{S_{n-1}}{\sqrt{n}}-\frac{1}{\sqrt{n}}\right)\right)^2\right].$$

5. 利用中心极限定理证明，当 $n\to\infty$ 时得到以下定理：

定理 9 (Gaussian–Poincaré)**.** 假设 $f:\mathbb{R}\to\mathbb{R}$ 是光滑函数，且 X 服从高斯分布 $X\sim\mathcal{N}(0,1)$，则

$$\operatorname{Var}[f(X)] \le \mathbb{E}[(f'(X))^2].$$

习题 2.2：用空腔法求随机场 Ising 模型

本习题的目标是用一种接近空腔法的技术，为随机场 Ising 模型的自由熵给出另一种推导。

1. 证明，向 N 个自旋的系统添加一个自旋后有

$$A_N(\beta,\Delta) =: \mathbb{E}_{\mathbf{h},h}\log\frac{Z_{N+1}}{Z_N} = \mathbb{E}_{\mathbf{h},h}\log\left\langle e^{-\frac{\beta}{2}\overline{S}^2}2\cosh\big(\beta(\overline{S}+h)\big)\right\rangle_{N,\beta,\mathbf{h}} + o(1).$$

2. 证明向哈密顿量加入外磁场 B（即加入一项 $B\sum_i S_i$）后，可以对几乎所有的 B 得到磁化强度的集中性，从而对任意 $\mathbf{h}$，有

$$\int_{B_1}^{B_2}\left(\langle\overline{S}^2\rangle_{N,\beta,\mathbf{h}} - \langle\overline{S}\rangle_{N,\beta,\mathbf{h}}^2\right)dB \le \frac{2}{\beta N}.$$

注意，这给出的是 Boltzmann 平均上的集中性，而非无序（场 $\mathbf{h}$）上的集中性。这意味着我们证明了磁化强度收敛到某个值 $m(\mathbf{h})$，该值先验上可能依赖于给定的无序实现 $\mathbf{h}$。

3. 解释为什么这蕴含，对几乎处处的 B，当 N 很大时，

$$A_N(\beta,\Delta,B) = \mathbb{E}_{\mathbf{h},h}\left[-\frac{\beta}{2}\langle\overline{S}\rangle_{N,\beta,\mathbf{h}}^2 + \log 2\cosh\big(\beta(\langle\overline{S}\rangle_{N,\beta,\mathbf{h}}+h+B)\big)\right] + o(1).$$

4. 既然已经证明，当 N 增大时 $\langle\overline{S}\rangle_{N,\beta,\mathbf{h}}$ 集中到一个值 $m(\mathbf{h})$，证明这蕴含当 $N\to\infty$ 时的界

$$\Phi(\beta,\Delta,B) \le \sup_m\left\{-\frac{\beta}{2}m^2 + \mathbb{E}_h\log 2\cosh(\beta(m+h+B))\right\}.$$

5. 使用第 1 讲的变分方法得到反向界，并最终证明

$$\Phi(\beta,\Delta) = \sup_m\left\{-\frac{\beta}{2}m^2 + \mathbb{E}_h\log 2\cosh(\beta(m+h))\right\}.$$

译注：第 2 小问积分方差界本身给出的是对 B 的积分控制；从该界得到逐点或几乎处处收敛时需说明具体的极限和附加条件。文中外场符号和角括号下标也按原文保留，具体约定需结合哈密顿量核查。

习题 2.3：RFIM 的平均场算法与状态演化

本习题的目标是给出一个寻找最低能量构型的算法，并分析其性质。

1. 使用第 1.3 节的变分方法或第 1.4 节的空腔法，解释为什么下面的迭代算法在实践中可能适合寻找最低能量（提示：这是一个有限温度迭代的零温极限）：

$$S_i^{t+1} = \operatorname{sign}\left(h_i + \sum_i S_i^t/N\right).$$

2. 编写这一算法的代码，验证系统足够大时，它确实找到了最小值与副本预测相符的构型。

3. 证明在大 N 极限下，该算法的动力学服从一个 “状态演化” 方程：即每个时间的平均磁化强度 $m^t = \sum_i S_i^t/N$ 由确定性方程给出：

$$m^{t+1} = \mathbb{E}_h \operatorname{sign}(h + m^t),$$

并由此得出：该算法正在对副本对称自由能方程 (2.2.3) 进行不动点迭代。

3 第一个应用：随机矩阵的谱

可惜，无法通过别人的讲述知道矩阵是什么。你必须亲自去看。

《黑客帝国》（Morpheus），1999

现在我们转向副本方法的第一个非平凡应用：计算随机矩阵的谱。Eugene Wigner 引入随机矩阵来为重原子核建模。他假设重原子核谱线之间的间距应当类似于随机矩阵特征值之间的间距，并且只依赖于底层演化的对称性类别。此后，随机矩阵的研究成为独立领域，应用范围从固态物理、量子混沌延伸到机器学习和数论。所有随机矩阵中最简单的是 Wigner 矩阵：

$$A_N = \frac{1}{\sqrt{2N}}(G + G^\top),$$

其中 G 是随机矩阵，每个元素 $G_{ij} \sim \mathcal{N}(0,1)$ 均独立地从 $\mathcal{N}(0,1)$ 抽取。核心问题是：当 $N \to \infty$ 时，这类随机矩阵的特征值分布 $\nu_{A_N}(\lambda)$ 是什么样的？结果发现，$\nu_{A_N}(\lambda)$ 收敛到一个定义良好的确定性函数 $\nu(\lambda)$。作为我们工具的第一个实际应用，我们将看到如何使用副本法和空腔法计算这一分布。

3.1 Stieltjes 变换

我们将使用称为 Stieltjes 变换的技术。它从一个在分布意义下定义、称为 Sokhotsky 公式的非常有用的恒等式开始。在物理学的场论中它常被称为 “Feynman 技巧”，也可用于计算光学中的 Kramers–Kronig 关系，或者定义因果函数的 Hilbert 变换。[5]

$$\delta(x - x_0) = -\lim_{\epsilon \to 0} \frac{1}{\pi} \operatorname{Im} \frac{1}{x - x_0 + i\epsilon}.$$

[5]原文脚注指出可通过复平面的 Cauchy 积分证明此公式，并给出另一种分解，具体见下文 “原文脚注”。

此公式是随机矩阵理论方法的基础。事实上，对于以均匀概率取 N 个值的概率分布 $\nu(x)$，有

$$\nu(x) = \frac{1}{N}\sum_i \delta(x - x_i) = -\lim_{\epsilon\to 0}\frac{1}{N\pi}\sum_i \operatorname{Im}\frac{1}{x - x_0 + i\epsilon}.$$

译注：上式右端照原文写为 x_0，但若与左端逐项对应，其分母应核查是否为 $x - x_i + i\epsilon$。

现在利用 $1/x$ 是对数的导数，写出

$$\frac{1}{N}\sum_i \frac{1}{x - x_i} = \frac{1}{N}\partial_x \sum_i \log(x - x_i) = \frac{1}{N}\partial_x \log\prod_i (x - x_i).$$

因此，给定一个特征值为 $\lambda_1, \ldots, \lambda_N$ 的 $N \times N$ 矩阵 A，利用行列式等于特征值的乘积，有

$$\nu(\lambda) = \frac{1}{N}\sum_i \delta(\lambda - \lambda_i) = -\frac{1}{N\pi}\operatorname{Im}\lim_{\epsilon\to 0}\partial_\lambda \log\det(A - (\lambda + i\epsilon)\mathbf{1}).$$

这是随机矩阵理论中计算技术的基础。对给定矩阵 A，我们将 Stieltjes 变换引入为

$$S_A(\lambda) = -\frac{1}{N}\sum_i \frac{1}{\lambda - \lambda_i} = -\frac{1}{N}\partial_\lambda \log\det(A - \lambda\mathbf{1}),$$

而一旦得到 Stieltjes 变换，就可以通过它的虚部取得概率密度：

$$\nu_A(\lambda) = \frac{1}{\pi}\lim_{\epsilon\to 0}\operatorname{Im} S_A(\lambda + i\epsilon).$$

因此，整个随机矩阵理论领域都归结为计算与特征值概率分布相关的 Stieltjes 变换。

原文脚注。 这个公式可以使用复平面上的 Cauchy 积分轻易证明。另一种做法是直接使用 $x^2 - \epsilon^2 = (x + i\epsilon)(x - i\epsilon)$。事实上，

$$\lim_{\epsilon\to 0^+}\int_{\mathbb{R}} \frac{f(x)}{x \pm i\epsilon}\,dx = \mp i\pi \lim_{\epsilon\to 0^+}\int_{\mathbb{R}} \frac{\epsilon}{\pi(x^2 + \epsilon^2)} f(x)\,dx + \lim_{\epsilon\to 0^+}\int_{\mathbb{R}} \frac{x^2}{x^2 + \epsilon^2}\frac{f(x)}{x}\,dx.$$

当 $\epsilon \to 0^+$ 时，第一个积分趋于 Dirac delta 函数（它是一个趋于 delta 的序列），因此第一项等于 $\mp i\pi f(0)$。第二项收敛到实的 Cauchy 主值积分，故

$$\operatorname{Im}\lim_{\epsilon\to 0^+}\int_{\mathbb{R}} \frac{f(x)}{x \pm i\epsilon}\,dx = \mp i\pi f(0) = \mp i\pi\int_{\mathbb{R}} \delta(x) f(x)\,dx. \tag{3.1}$$

译注：脚注中的 $x^2 - \epsilon^2$ 照原文保留；右侧实际展开为 $x^2 + \epsilon^2$。式 (3.1) 的左侧为虚部，而右侧仍带 i，对实值 f 需核查该因子；相关分布极限亦需在适当测试函数条件下理解。

3.2 副本方法

我们的目标是使用副本方法计算 Wigner 矩阵的 Stieltjes 变换。这里我们不追求数学严格性，因为目的仅是展示这一工具的威力。

3.2.1 对副本取平均

假设 Stieltjes 变换和特征值密度都是自平均的，我们需要计算大系统尺寸极限下的期望：

$$\lim_{N\to\infty}\mathbb{E}S_{A_N}(\lambda)=-\partial_\lambda\lim_{N\to\infty}\frac{1}{N}\mathbb{E}\log\det(A_N-\lambda I_N). \tag{3.2}$$

我们不直接对 log-det 使用副本技巧，而是采用以下更实用的方法：

$$\mathbb{E}\log\det(A_N-\lambda I_N)=-2\mathbb{E}\log\left[\det(A_N-\lambda I_N)^{-1/2}\right].$$

因此，遵循通过计算 $(X^n-1)/n$ 来计算 $\log X$ 的副本策略，需要计算 $\det(A_N-\lambda I_N)^{-1/2}$ 的 n 次幂的平均。现在使用高斯积分，将行列式平方根表示成积分：

$$\begin{aligned}\mathbb{E}\det(A_N-\lambda I_N)^{-n/2}&=\mathbb{E}\left[\prod_{a=1}^{n}\int_{\mathbb{R}^N}\frac{dx}{(2\pi)^{N/2}}e^{-\frac{1}{2}x^\top(A_N-\lambda I_N)x}\right]\\&=\int_{\mathbb{R}^N}\prod_{a=1}^{n}\frac{dx^a}{(2\pi)^{N/2}}e^{\frac{\lambda}{2}\sum_{a=1}^n\|x^a\|_2^2}\mathbb{E}\left[e^{-\frac{1}{2}\sum_{a=1}^n x^{a\top}A_N x^a}\right].\end{aligned} \tag{3.3}$$

译注： 原文此处未充分说明行列式平方根与对数的分支及高斯积分的收敛区域；在谱内使用 Stieltjes 边界值时，还需说明从可收敛区域解析延拓的条件。上述等式按源文保留。

对于我们的 Wigner 矩阵（所谓 GOE(N) 系综），可以写 $A=(G+G^\top)/\sqrt{2N}$，其中 $G\sim\mathcal{N}(0,1)$ 独立同分布。因此式 (3.3) 中的平均可写为

$$\mathbb{E}_A\left[e^{-\frac{1}{2}\sum_{a=1}^n x^{a\top}A_N x^a}\right]=\mathbb{E}_G\left[e^{-\frac{1}{\sqrt{2N}}\sum_{a=1}^n x^aGx^a}\right]=\prod_{ij}\mathbb{E}_{G_{ij}}\left[e^{-\frac{G_{ij}}{\sqrt{2N}}\sum_{a=1}^n x_i^a x_j^a}\right].$$

此时复习高斯积分是个好主意，因为我们将经常使用它。特别地，有

$$\int e^{-ax^2+bx}\,dx=\sqrt{\frac{\pi}{a}}\,e^{b^2/(4a)},\qquad\text{或}\qquad\mathbb{E}_x[e^{bx}]=e^{b^2/(2a)}.$$

从而

$$\mathbb{E}_A\left[e^{-\frac{1}{2}\sum_{a=1}^n x^{a\top}A_N x^a}\right]=\prod_{ij}e^{\frac{1}{4N}(\sum_{a=1}^n x_i^a x_j^a)^2}=\prod_{ij}e^{\frac{N}{4}\sum_{a,b=1}^n\frac{x_i^a x_j^a x_i^b x_j^b}{N^2}}=e^{\frac{N}{4}\sum_{a,b=1}^n(\frac{x^a\cdot x^b}{N})^2}.$$

原文脚注。 高斯分布归一化为

$$\frac{1}{\sqrt{\det(A_N-\lambda I_N)}}\int_{\mathbb{R}^N}\frac{dx}{(2\pi)^{N/2}}e^{-\frac{1}{2}x^\top(A_N-\lambda I_N)x}=1.$$

更一般的一个公式据称用于 90% 的副本计算：若 A 是对称正定矩阵，则

$$\int e^{-\frac{1}{2}x^TAx+B^Tx}\,d^nx=\sqrt{\frac{(2\pi)^n}{\det A}}\,e^{\frac{1}{2}B^TA^{-1}B}.$$

译注： 脚注第一个归一化式照原文保留；对正定矩阵直接计算，该积分为 $1/\sqrt{\det(A_N-\lambda I_N)}$，所以使其归一化的乘子应核查是否为 $\sqrt{\det(A_N-\lambda I_N)}$。上文 $\mathbb{E}_x[e^{bx}]$ 的参数 a 也需结合所取高斯方差说明；不能仅由积分式在未指定分布时直接推定。

这是副本计算中非常典型的一步！我们现已完成对无序（随机性）的积分，得到

$$\mathbb{E}\det(A_N-\lambda I_N)^{-n/2}=\int_{\mathbb{R}^N}\prod_{a=1}^{n}\frac{dx^a}{(2\pi)^{N/2}}e^{N\frac{\lambda}{2}\sum_{a=1}^{n}(\frac{1}{N}x^a\cdot x^a)+\frac{N}{4}\sum_{a,b=1}^{n}(\frac{1}{N}x^a\cdot x^b)^2}.$$

一个非常重要的现象发生了：对无序的积分将此前独立的副本“耦合”在一起。对无序积分时确实总会发生这种情况。耦合副本的这个新项至关重要，并有自己的名字：副本间的重叠。因此定义

$$q^{ab}=:\frac{1}{N}x^a\cdot x^b.$$

现在引入“delta 函数”以释放重叠序参量，就像先前处理随机场 Ising 模型的磁化强度时那样。对于任意函数 f，有

$$f\left(\frac{1}{N}x^a\cdot x^b\right)=N^n\int\prod_{1\le a\le b\le n}dq^{ab}\,\delta(Nq^{ab}-x^a\cdot x^b)\,f(x^a\cdot x^b).$$

和以前一样，舍去 N^n 的系数，因为最终要取归一化对数并令 $N\to\infty$，然后写出

$$\mathbb{E}\det(A_N-\lambda I_N)^{-n/2}\approx\int\prod_{1\le a\le b\le n}\delta\left(q^{ab}-\frac{x^a\cdot x^b}{N}\right)dq^{ab}\,e^{\frac{N\lambda}{2}\sum_{a=1}^{n}q^{aa}+\frac{N}{4}\sum_{a,b=1}^{n}(q^{ab})^2}.\tag{3.4}$$

译注：上面两式依原文保留；第一式对任意 f 的变量缩放及 N 的幂次、式 (3.4) 中对 x 的积分是否被省略，均需核查。取极限前不能仅凭这些记号视作严格恒等式。

完全重复前几章的步骤，现在取 delta 函数的 Fourier 表示（并换元使它们看上去“实”而非“复”）：

$$\prod_{1\le a\le b\le n}\delta(Nq^{ab}-x^a\cdot x^b)=\int\prod_{1\le a\le b\le n}\frac{d\widehat{q}^{ab}}{2\pi}\,e^{-\sum_{1\le a\le b\le n}\widehat{q}^{ab}(Nq^{ab}-x^a\cdot x^b)},$$

将其代入后便可写成

$$\mathbb{E}\det(A_N-\lambda I_N)^{-n/2}\approx\int\prod_{1\le a\le b\le n}\frac{dq^{ab}d\widehat{q}^{ab}}{2\pi}\,e^{N\Phi(q^{ab},\widehat{q}^{ab})},\tag{3.5}$$

其中

$$\Phi(q^{ab},\widehat{q}^{ab})=-\sum_{1\le a\le b\le n}\widehat{q}^{ab}q^{ab}+\frac{\lambda}{2}\sum_{a=1}^{n}q^{aa}+\frac{1}{4}\sum_{a,b=1}^{n}(q^{ab})^2+\Psi_x(\widehat{q}^{ab}),$$

并且（各位置现已解耦）

$$\begin{aligned}\Psi_x(\widehat{q}^{ab})&=\frac{1}{N}\log\int\prod_{a=1}^{n}\frac{dx^a}{(2\pi)^{N/2}}e^{\sum_{1\le a\le b\le n}\widehat{q}^{ab}x^a\cdot x^b}\\&=\frac{1}{N}\log\left(\int\prod_{a=1}^{n}\frac{dx^a}{\sqrt{2\pi}}e^{\sum_{1\le a\le b\le n}x^a\widehat{q}^{ab}x^b}\right)^N\\&=\log\int\prod_{a=1}^{n}\frac{dx^a}{\sqrt{2\pi}}e^{\sum_{1\le a\le b\le n}x^a\widehat{q}^{ab}x^b}.\end{aligned}$$

当 $N\to\infty$ 时，式 (3.5) 中的积分可以用鞍点法计算，因此

$$\mathbb{E}\det(A_N-\lambda I_N)^{-n/2}\approx\exp\left[N\operatorname{extr}_{q^{ab},\widehat{q}^{ab}}\Phi(q^{ab},\widehat{q}^{ab})\right].$$

这就完成了副本计算。

3.2.2 副本对称假设

我们再次遇到一个函数的极值问题，但这一次要在一个 $n \times n$ 矩阵空间上求极值，这看起来相当复杂。为了推进极值问题，我们可以将搜索限制在特定解上，并再次假设副本对称性：

$$q^{ab} = \delta^{ab} q, \qquad \widehat{q}^{ab} = -\frac{1}{2}\delta^{ab}\widehat{q}.$$

在这个假设下，

$$\sum_{1\le a\le b\le n} \widehat{q}^{ab} q^{ab} = -\frac{n}{2}\widehat{q}q, \qquad \sum_{a=1}^{n} q^{aa} = nq, \qquad \sum_{a,b=1}^{n} (q^{ab})^2 = nq^2.$$

最后，

$$\Psi_x(\widehat{q}) = \log \int \prod_{a=1}^{n} \frac{dx^a}{\sqrt{2\pi}} e^{\widehat{q}\sum_{a=1}^{n}(x^a)^2} = n \log \int \frac{dx}{\sqrt{2\pi}} e^{-\frac{1}{2}\widehat{q}x^2} = -\frac{n}{2}\log \widehat{q}.$$

译注： 第一项的指数照原文写为 $\widehat{q}\sum_a (x^a)^2$，但由上面的对角假设直接代入应核查其是否应为 $-\frac{1}{2}\widehat{q}\sum_a (x^a)^2$；原式的第一、二项一般并不相等。积分还需适当的收敛条件。

把这些合并并应用鞍点法，就得到

$$\begin{aligned} -\frac{2}{N}\mathbb{E}\log\det(A_n - \lambda I_n)^{-1/2} &\approx -2\lim_{n\to 0} \frac{e^{-\frac{nN}{2}\operatorname{extr}_{q,\widehat{q}}\{\log\widehat{q} - \widehat{q}q - \lambda q - \frac{1}{2}q^2\}} - 1}{n} \\ &\approx \operatorname{extr}\left\{\log\widehat{q} - \widehat{q}q - \lambda q - \frac{1}{2}q^2\right\}. \end{aligned}$$

为了求解，考察对参数 $(q, \widehat{q})$ 求导得到的鞍点方程：

$$\widehat{q} = \frac{1}{q}, \qquad q = -\widehat{q} - \lambda \qquad \Longleftrightarrow \qquad \frac{1}{q} + q + \lambda = 0.$$

它有两个解：

$$q_{\pm}^{*} = \frac{-\lambda \pm \sqrt{\lambda^2 - 4}}{2}.$$

最后，利用式 (3.2) 得到 Stieltjes 变换：

$$\lim_{N\to\infty} \mathbb{E}S_{A_N}(\lambda) = -\partial_\lambda \lim_{N\to\infty} \frac{1}{N}\mathbb{E}\log\det(A - \lambda I_N) = q_{\pm}^{*} = \frac{-\lambda \pm \sqrt{\lambda^2 - 4}}{2}.$$

因此我们找到了 Stieltjes 变换，而当 $\lambda > 0$ 与 $\lambda < 0$ 时都有两个（!）解。对 Stieltjes 变换求逆时只有一个是正确的，但检查哪一个并不困难，因为概率必须为正。

译注： 从 $\mathbb{E}[\det(\cdot)^{-n/2}]$ 到归一化对数的副本极限需要说明 N, n 的极限次序；上式左侧带 $1/N$ 而右侧第一行未显式包含它，且原文在该式写 A_n, I_n。译稿保留源文，这些归一化和指标需进一步核查。选取平方根分支时除密度非负外，也需考虑解析性和大 $|\lambda|$ 的渐近行为。

3.2.3 从 Stieltjes 变换到谱

现在可以利用以下关系计算谱：

$$\nu_A(\lambda) = \frac{1}{\pi}\lim_{\epsilon\to 0} \operatorname{Im} S_A(\lambda + i\epsilon).$$

第一项 $-\lambda$ 不涉及非平凡的计算，我们集中讨论第二项。当 $|\lambda|>2$ 时，

$$\sqrt{(\lambda+i\epsilon)^2-4}=\sqrt{\lambda^2-\epsilon^2-4+2i\epsilon\lambda}\approx\sqrt{\lambda^2-\epsilon^2-4}\left(1-\frac{i\epsilon\lambda}{\lambda^2-\epsilon^2-4}\right),$$

当 $\epsilon\to 0$ 时它同样没有虚部。因此我们只能得出结论：当 $|\lambda|>2$ 时 $\nu(\lambda)=0$。另一方面，如果 $|\lambda|<2$，则

$$\sqrt{(\lambda+i\epsilon)^2-4}\approx\sqrt{\lambda^2-\epsilon^2-4}\sqrt{1-\frac{i\epsilon\lambda}{\lambda^2-\epsilon^2-4}}=i\sqrt{4-\lambda^2}+O(\epsilon),$$

从而（最终为了得到正的分布，将正确的副本解选为“+”）发现

$$\nu(\lambda)=\frac{1}{2\pi}\sqrt{4-\lambda^2}\qquad \text{若}2>\lambda>-2,$$
$$\nu(\lambda)=0\qquad \text{其他情形.}$$

这确实是正确的 Wigner 解，也就是著名的“半圆”定律。**译注：**平方根的上述展开按原文保留；

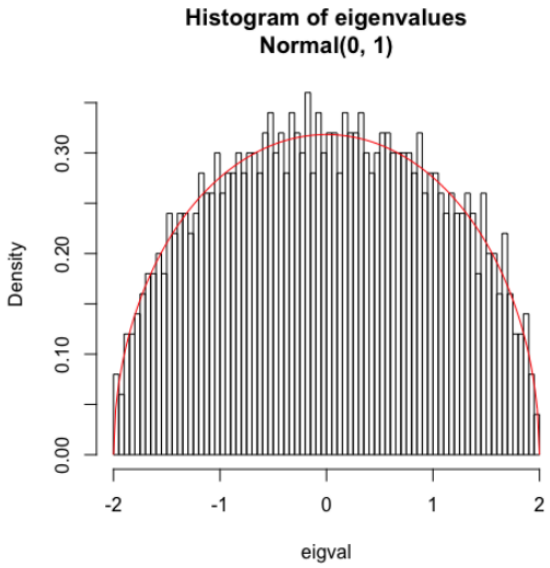


图 3.2.1: 使用一个 1000 × 1000 Wigner 矩阵模拟半圆定律。图中 Histogram of eigenvalues、Density 和 eigval 分别表示特征值直方图、密度和特征值。

直接将 $\lambda^2-\epsilon^2-4+2i\epsilon\lambda$ 因式分解后，一阶项符号与原文中的减号需核查。复平方根在不同实轴区间上的分支不能统一凭实变量的正负号选择；这里的处理是形式性的。

3.3 空腔方法

使用空腔法代替副本法计算 Stieltjes 变换是一个有用的练习。我们从定义出发：

$$S_{A_N}(\lambda)=-\frac{1}{N}\sum_i\frac{1}{\lambda-\lambda_i}.$$

空腔计算的思想是寻找 $N\times N$ 矩阵与 $(N+1)\times(N+1)$ 矩阵的变换之间的递推方程。定义

$$M_N=\lambda\mathbf{1}-A_N,\qquad\qquad R_N=[\lambda\mathbf{1}-A_N]^{-1}=M_N^{-1},$$

其中 R_N 称为预解矩阵。利用通过代数余子式矩阵计算矩阵逆的公式，得到

$$(R_{N+1})_{N+1,N+1} = \frac{\det M_N}{\det M_{N+1}}.$$

此外，我们可以沿最后一行、再沿最后一列做 Laplace 展开，计算 $N+1$ 维矩阵的行列式，从而

$$\det M_{N+1} = (M_{N+1})_{N+1,N+1} \det M_N - \sum_{k,l=1}^{N} (M_{N+1})_{N+1,k}(M_{N+1})_{l,N+1} C^N_{l,k},$$

其中 $C^N_{l,k}$ 为 M_N 的代数余子式矩阵。将上式除以 $\det M_N$，得到

$$\begin{aligned}
\frac{\det M_{N+1}}{\det M_n} &= \frac{1}{(R_{N+1})_{N+1,N+1}} \\
&= (M_{N+1})_{N+1,N+1} - \frac{1}{\det M_N} \sum_{k,l=1}^{N} (M_{N+1})_{N+1,k}(M_{N+1})_{l,N+1} C^N_{l,k} \\
&= \lambda - (A_{N+1})_{N+1,N+1} - \sum_{k,l=1}^{N} (A_{N+1})_{N+1,k}(A_{N+1})_{l,N+1}(R_N)_{k,l}.
\end{aligned}$$

此时我们额外假设预解矩阵 R_N 的非对角元为 $O(N^{-1/2})$。例如，可以用微扰理论按 λ 的幂展开，观察在该展开的每一阶中非对角元确实为 $N^{-1/2}$ 阶，以此加以检验。在此情况下，方程进一步简化为

$$(R_{N+1})_{N+1,N+1} = \frac{1}{\lambda - N^{-1} \sum_{l=1}^{N} (R_N)_{l,l}},$$

其中使用了 A_N 具有独立同分布元素。由于 R_{N+1} 的对角矩阵元同分布，我们发现

$$\frac{1}{N} \operatorname{Tr} R_{N+1} = \frac{1}{\lambda - \frac{1}{N} \operatorname{Tr} R_N},$$

因此 Stieltjes 变换满足

$$S_{A_{N+1}}(\lambda) = -\frac{1}{\lambda + S_{A_N}(\lambda)},$$

于是我们预期，随着 N 增大，Stieltjes 变换将收敛到不动点。这确实与副本方法得到的（正确）方程相同。因此，我们已检验两种方法在此情形下都给出正确解。

译注： 本段保持原文的有限 N 等号及 $\det M_n$ 记号。按前文定义，A_N 为对称矩阵，$A_{ij} = A_{ji}$，故其全部矩阵元素并非彼此独立；从随机二次型到迹的替换、从同分布到单次实现的等式，以及 N 与 $N+1$ 归一化都需说明极限与集中条件。逐阶微扰中元素的估计也不能直接替代在谱边界上的统一控制；这些问题并不单独否定大 N 的目标结果。

文献说明。 著名的 Wigner 随机矩阵由 Wigner (1958) 引入。随机矩阵中副本方法的应用始于 Edwards 和 Jones 的开创性工作 (Edwards 和 Jones, 1976)。如今这已发展成独立领域，并有数百个深刻而非平凡的结果。关于该主题的优秀讲义可见 Livan 等 (2018) 与 Potters 和 Bouchaud (2020)；经典数学参考资料为 Bai 和 Silverstein (2010)。

3.4 习题

习题 3.1：Wishart 矩阵或 Marčenko–Pastur 定律

本习题的目标是对 Wishart 矩阵重复副本计算，并推导其特征值分布，也称为 Marčenko–Pastur 定律。Wishart 矩阵定义如下：考虑一个 $M \times N$ 随机矩阵 X，其元素独立同分布，服从标准高斯分布 $\mathcal{N}(0,1)$。Wishart 矩阵 $\widehat{\Sigma}$ 为

$$\widehat{\Sigma} =: \frac{1}{N} X X^T.$$

换言之，它们是随机数据点之间的相关矩阵。因此，这类矩阵在数据科学和机器学习的许多具体情形中被使用，特别是用于从数据噪声中滤出信号。

1. 记 $\alpha = M/N$，在 $M, N \to \infty$ 且 α 固定的极限下，对 Wishart 矩阵重复 Stieltjes 变换的副本计算。证明其结果为
$$S_{\widehat{\Sigma}}(\lambda) = \frac{1 - \alpha - \lambda \pm \sqrt{(\lambda - \alpha - 1)^2 - 4\alpha}}{2\alpha\lambda}.$$

2. 对 $\alpha < 1$，证明这给出特征值分布的 Marčenko–Pastur 定律：
$$\nu_{\widehat{\Sigma}}(\lambda) = \frac{1}{2\pi} \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{\alpha\lambda}, \qquad \lambda \in [\lambda_-, \lambda_+],$$
$$\lambda_\pm = (1 \pm \sqrt{\alpha})^2.$$

3. 对大的 M, N 模拟这类随机矩阵，并检验你对特征值分布的预测。

4. 换成 $\alpha > 1$ 重复模拟，再次与分布 $\nu_{\widehat{\Sigma}}(\lambda)$ 比较。我们是否遗漏了什么？提示：delta 函数 $\delta(\lambda)$ 的 Stieltjes 变换为 $-1/\lambda$。

4 随机图上的随机场 Ising 模型

我想我永远不会看到，

像一棵树一样美丽的诗篇。

Joyce Kilmer，1913

我们将继续探索随机场 Ising 模型的 Boltzmann–Gibbs 分布

$$P_{N,\beta}(S = s) = \frac{e^{-\beta \mathcal{H}(s)}}{Z_N(\beta)},$$

但现在考虑一种更复杂、更有趣的拓扑。假设存在一个连接部分节点的图 G_{ij}：若 i 与 j 相连，则 $G_{ij} = 1$，否则为 0。此前各章只处理完全连接图，即对所有 i, j 有 $G_{ij} = 1$ 的情形。现在哈密顿量可写为

$$\mathcal{H}_{N,J,\{h\},G}(s) = -J \sum_{(i,j)\in G} S_i S_j - \sum_{i=1}^{N} h_i S_i,$$

其中 J 是标量耦合常数。

4.1 所有空腔论证的根源

假设有 N 个彼此孤立的自旋 $i=1,\dots,N$。此时其概率分布足够简单，$m_i=\tanh(\beta h_i)$。现在设想按照空腔方法的精神，将这 N 个自旋连接到一个新自旋 S_0。当然，m_i 现在会改变！因此我们将旧的 m_i 值称作“空腔值”，写为

$$m_i^c \equiv \tanh \beta h_i.$$

根据此定义，注意 $(1+S_i m_i^c)/2 = e^{\beta h_i S_i}/\cosh(\beta h_i)$。我们关心的主要问题是：能否把新自旋的磁化强度 m_0 写成 $\{m_i^c\}$ 的函数？让我们试试看！显然，

$$\begin{aligned} m_0 &= \frac{\sum_{S_0,\{s\}} S_0 e^{\beta S_0 h_0 + \sum_i \beta J S_i S_0 + \beta S_i h_i}}{\sum_{S_0,\{s\}} e^{\beta S_0 h_0 + \sum_i \beta J S_i S_0 + \beta S_i h_i}} \\ &= \frac{\sum_{S_0} S_0 e^{\beta S_0 h_0} \prod_i \sum_{S_i} e^{\beta J S_i S_0} \frac{1+S_i m_i^c}{2}}{\sum_{S_0} e^{\beta S_0 h_0} \prod_i \sum_{S_i} e^{\beta J S_i S_0} \frac{1+S_i m_i^c}{2}} \\ &= \frac{X^+ - X^-}{X^+ X^-}, \qquad X^s = e^{\beta s h_0} \prod_i \sum_{S_i} e^{\beta J S_i s} \frac{1+S_i m_i^c}{2}. \end{aligned}$$

译注：上面原文所写的单自旋概率等式右端缺少因子 $1/2$；末行分母印为 X^+X^-，而由前一行及紧接的推导可见需核查是否应为 $X^+ + X^-$。这两处按原文保留，后续结论不应由所印等式直接推得。

利用恒等式 $\operatorname{atanh} x = \frac{1}{2}\log\frac{1+x}{1-x}$ 并对两边取 atanh，得到

$$\begin{aligned} \operatorname{atanh}(m_0) &= \frac{1}{2}\log\frac{1+\frac{X^+-X^-}{X^++X^-}}{1-\frac{X^+-X^-}{X^++X^-}} = \frac{1}{2}\log\frac{X^+}{X^-} \\ &= \beta h_0 + \sum_i \frac{1}{2}\log\frac{e^{\beta J}(1+m_i^c)+e^{-\beta J}(1-m_i^c)}{e^{-\beta J}(1+m_i^c)+e^{\beta J}(1-m_i^c)} \\ &= \beta h_0 + \sum_i \frac{1}{2}\log\frac{\cosh(\beta J)+m_i^c\sinh(\beta J)}{\cosh(\beta J)-m_i^c\sinh(\beta J)} \\ &= \beta h_0 + \sum_i \frac{1}{2}\log\frac{1+m_i^c\tanh(\beta J)}{1-m_i^c\tanh(\beta J)} \\ &= \beta h_0 + \sum_i \operatorname{atanh}(m_i^c \tanh(\beta J)). \end{aligned}$$

于是最终可以用相对简单的形式，将新自旋的磁化强度写成“旧”系统中自旋的函数：

$$m_0 = \tanh\left(\beta h_0 + \sum_i \operatorname{atanh}(m_i^c \tanh(\beta J))\right). \tag{4.1}$$

4.2 树上的精确递推

在树上迭代重复相同的论证相当简单。从初始条件出发，在树的任意一层可以写

$$m_{i\to j} = \tanh\left(\beta h_i + \sum_{k\in\partial i\neq j} \operatorname{atanh}(m_{k\to i}\tanh(\beta J))\right). \tag{4.2}$$

如果我们想知道真正的边缘分布呢？这很容易，只需写出

$$m_i = \tanh\left(\beta h_i + \sum_{k\in\partial i} \operatorname{atanh}(m_{k\to i}\tanh(\beta J))\right). \tag{4.3}$$

这就是所谓信念传播方法的根源。我们求解空腔边缘量 $m_{i\to j}$，它可以方便地解释为一个消息传递问题。一旦全部求得，便可计算真正的边缘分布！

这种方法最初出现在统计物理中，当时 Bethe 与 Peierls 将其用于近似正则晶格。事实上，我们可以在连接度例如为 $c = 2d$ 的大无穷树上迭代这一方法，来近似 d 维超立方晶格（其中每个节点有 $2d$ 个邻居）。例如考虑零场情况。此时距叶子距离为 ℓ 的磁化强度满足

$$m^{\ell+1} = \tanh\Big((c-1)\operatorname{atanh}(m^{\ell}\tanh(\beta J))\Big).$$

我们可以寻找此方程的不动点，并检验对于哪些逆温度磁化强度可能取非零值。这与 Ising 模型中的现象相同，只是不动点稍复杂一些。通过绘制此方程，可以发现：假设 $d = 2c$，当 $d = 1$ 时这一现象发生在 $\beta^{\mathrm{BP}} = \infty$；$d = 2$ 时为 $\beta^{\mathrm{BP}} = 0.346$；$d = 3$ 时为 0.203；$d = 4$ 时为 0.144；$d = 5$ 时为 0.112。若将这些数字与真正超立方晶格上的相变比较，可得 $d = 1$ 时 $\beta^{\mathrm{lattice}} = \infty$，$d = 2$ 时为 0.44，$d = 3$ 时为 0.221，$d = 4$ 时为 0.149，$d = 5$ 时为 0.114。相当不错！事实上可以看到，随着 d 增大，预测变得精确。这一方法对于估计临界温度非常好。实际上，可以证明它对任意拓扑的铁磁相变给出严格上界！

译注： 本段“假设 $d = 2c$”按原文保留，但与本段前面 $c = 2d$ 的约定不一致；数值比较还需要明确 J 的取值。“任意拓扑的严格上界”等结论的适用定义与条件亦需核查，不能从该段的递推例子直接推广。

4.2.1 两体模型在树上的信念传播

刚才讨论的迭代方法可以在树图上作完全一般化！目前考虑的例子以完全一般的形式写成

$$\mathcal{H} = -\sum_{(ij)\in G} J_{ij}S_iS_j - \sum_i h_iS_i.$$

它是一类非常一般的模型的一个例子：具有两体相互作用的模型，其中每个构型的概率为

$$P((S)) = \frac{1}{Z}\left[\prod_i \psi_i(S_i)\prod_{(ij)\in G}\psi_{ij}(S_i,S_j)\right],$$

$$Z = \sum_{\{S_{i=1,\dots,N}\}}\left[\prod_i \psi_i(S_i)\prod_{(ij)\in G}\psi_{ij}(S_i,S_j)\right],$$

一旦定义 $\psi_{ij}(S_i,S_j) = \exp(\beta J_{ij}S_iS_j)$ 和 $\psi_i(S_i) = \exp(\beta h_iS_i)$，这一联系便很清楚。

我们希望像处理 RFIM 那样计算树上的 Z。对于相邻位置 i,j，我们考虑变量 $Z_{i\to j}(S_i)$，它定义为以 i 为根、排除通向 j 的分支、且第 i 个自旋变量固定为 S_i 时的子树部分配分函数。还需要引入 $Z_i(S_i)$，它是在变量 i 同样固定为 S_i 时整棵树的配分函数。在树上，可以按照以下递推精确计算这些中间变量：

$$Z_{i\to j}(S_i) = \psi_i(S_i)\prod_{k\in\partial i\setminus j}\left(\sum_{S_k} Z_{k\to i}(S_k)\psi_{ik}(S_i,S_k)\right), \tag{4.4}$$

$$Z_i(S_i) = \psi_i(S_i) \prod_{j\in\partial i} \left(\sum_{S_j} Z_{j\to i}(S_j)\psi_{ij}(S_i, S_j) \right), \tag{4.5}$$

其中 ∂i 表示 i 的所有邻居构成的集合。为写出这些方程，唯一作出的假设是：对所有不同的 $k, k' \in \partial i \setminus j$，消息 $Z_{k\to i}(S_k)$ 和 $Z_{k'\to i}(S_{k'})$ 彼此独立。在树上这显然成立：由于没有环，位置 k 与 k' 只能通过 i 连接，而考虑部分量时我们已经“切断”这一相互作用。这一递推在精神上与一维链的标准转移矩阵方法非常相似。

然而，在实践中，直接使用配分函数（它们是可能随系统大小指数增长的数）有些不便。因此可以将式 (4.4) 归一化，并用概率重写这些递推。记 $\eta_{i\to j}(S_i)$ 为移去边 (ij) 后变量 S_i 的边缘概率分布，则

$$\eta_{i\to j}(S_i) = \frac{Z_{i\to j}(S_i)}{\sum_{S_i'} Z_{i\to j}(S_i')}, \qquad \eta_i(S_i) = \frac{Z_i(S_i)}{\sum_{S_i'} Z_i(S_i')}.$$

于是递推式 (4.4) 和 (4.5) 变成

$$\eta_{i\to j}(S_i) = \frac{\psi_i(S_i)}{z_{i\to j}} \prod_{k\in\partial i\setminus j} \left(\sum_{S_k} \eta_{k\to i}(S_k)\psi_{ik}(S_i, S_k) \right), \tag{4.6}$$

$$\eta_i(S_i) = \frac{\psi_i(S_i)}{z_i} \prod_{j\in\partial i} \left(\sum_{S_j} \eta_{j\to i}(S_j)\psi_{ij}(S_i, S_j) \right), \tag{4.7}$$

其中 $z_{i\to j}$ 和 z_i 是归一化常数，定义为

$$z_{i\to j} = \sum_{S_i} \psi_i(S_i) \prod_{k\in\partial i\setminus j} \left(\sum_{S_k} \eta_{k\to i}(S_k)\psi_{ik}(S_i, S_k) \right), \tag{4.8}$$

$$z_i = \sum_{S_i} \psi_i(S_i) \prod_{j\in\partial i} \left(\sum_{S_j} \eta_{j\to i}(S_j)\psi_{ij}(S_i, S_j) \right). \tag{4.9}$$

迭代方程 (4.6)、(4.7) 及归一化方程 (4.8)、(4.9) 称为信念传播方程。由于 $\eta_{i\to j}(S_i)$ 是与变量 j 相连的边不存在时变量 S_i 的分布，可以方便地将它解释为不存在 j 时关于 S_i 的概率“信念”。它也称为“空腔”概率，因为它通过从图中移去一个节点得到。信念传播方程用于定义信念传播算法：

1. 随机初始化空腔消息（或信念）$\eta_{i\to j}(S_i)$；若有先验信息，也可依据 $\psi_i(S_i)$ 初始化。
2. 按随机顺序，依据递推式 (4.6)、(4.7) 更新消息，直至收敛到不动点。
3. 收敛后，用信念计算每个变量的完整边缘概率分布 $\eta_i(S_i)$。这是变量 i 的边缘概率分布的信念传播估计。

利用所得边缘分布，例如可以通过 $m_i = \langle S_i \rangle = \sum_{S_i} \eta_i(S_i)S_i$ 计算平衡局部磁化强度，也可以计算基本上任何其他感兴趣的局部量。

此时，既然我们从部分配分和转向了部分边缘分布，敏锐的读者可能会抱怨我们忽略了最初的目标：计算配分函数。幸运的是，可以根据边缘分布计算配分函数。为此，首先对每条边 (ij)

定义

$$z_{ij} = \sum_{S_i,S_j} \eta_{j\to i}(S_j)\eta_{i\to j}(S_i)\psi_{ij}(S_i,S_j) = \frac{z_j}{z_{j\to i}} = \frac{z_i}{z_{i\to j}},$$

其中最后两个等式由将式 (4.6) 代入第一个等式并注意到它几乎给出式 (4.9) 得到。再次使用式 (4.6) 和 (4.9)，得到

$$\begin{aligned} z_i &= \sum_{S_i} \psi_i(S_i) \prod_{j\in\partial i} \left(\sum_{S_j} \eta_{j\to i}(S_j)\psi_{ij}(S_i,S_j) \right) \\ &= \sum_{S_i} \psi_i(S_i) \prod_{j\in\partial i} \left(\sum_{S_j} \frac{Z_{j\to i}(S_j)}{\sum_{S'_j} Z_{j\to i}(S'_j)} \psi_{ij}(S_i,S_j) \right) = \frac{\sum_{S_i} Z_i(S_i)}{\prod_{j\in\partial i} \sum_{S_j} Z_{j\to i}(S_j)}, \end{aligned}$$

并以同样的步骤得到

$$z_{j\to i} = \frac{\sum_{S_j} Z_{j\to i}(S_j)}{\prod_{k\in\partial j\setminus i} \sum_{S_k} Z_{k\to j}(S_k)}.$$

对于任意自旋 S_i，总配分函数可由 $Z = \sum_{S_i} Z_i(S_i)$ 得到。因此，我们可以从任意自旋 i 开始：

$$Z = \sum_{S_i} Z_i(S_i) = z_i \prod_{j\in\partial i} \left(\sum_{S_j} Z_{j\to i}(S_j) \right) = z_i \prod_{j\in\partial i} \left(z_{j\to i} \prod_{k\in\partial j\setminus i} \sum_{S_k} Z_{k\to j}(S_k) \right),$$

继续迭代这一关系直至到达树的叶子。利用上面的 z_{ij} 表达式，得到

$$Z = z_i \prod_{j\in\partial i} \left(z_{j\to i} \prod_{k\in\partial j\setminus i} z_{k\to j} \cdots \right) = z_i \prod_{j\in\partial i} \left(\frac{z_j}{z_{ij}} \prod_{k\in\partial j\setminus i} \frac{z_k}{z_{jk}} \cdots \right) = \frac{\prod_i z_i}{\prod_{(ij)} z_{ij}}.$$

因此得到自由能的一个方便形式，可以直接从空腔消息计算；它常被称为树上的 Bethe 自由能：

$$f_{\mathrm{Tree}} N = -T \log Z = \sum_i f_i - \sum_{(ij)} f_{ij}, \qquad f_i = -T \log z_i, \qquad f_{ij} = -T \log z_{ij}.$$

其中 f_i 是来自位置 i 的边缘分布归一化的 “位置项”，与向系统添加位置 i（以及相应边）时 Z 的变化有关。另一方面，f_{ij} 是 “边项”，可以解释为添加边 (ij) 时 Z 的变化。这为 Bethe 自由能方程提供了方便的解释：它是所有位置自由能 f_i 之和，但由于每条边被计数两次，需通过减去 f_{ij} 作修正。

至此我们已经完全解决了树上的问题。然而，没有什么阻止我们将同样策略应用到任意图上。事实上，我们所描述的算法在任意图上都有良好定义，但无法保证它给出精确结果，也无法保证它会收敛。在含环图上使用这些方程，在贝叶斯推断文献中有时称为*有环信念传播*。

人们可能会问 BP 方法与变分方法之间是否存在联系。甚至可能会问，这是否与使用一种比朴素平均场方法更好的方式来应用变分界相同！遗憾的是，答案是否定的！我们不能一般性地证明 BP 自由熵是任意图上的下界：确实存在它大于 $\log Z$ 的例子，也存在它小于 $\log Z$ 的例子。

两点重要说明：

- 不过，变分方法和 BP 方法之间确实存在联系。如果写出变分方法，并对试探分布采用以下参数化（其中 $c_i = |\partial i|$）：

$$Q(S) = \frac{\prod_{ij} b_{ij}(S_i, S_j)}{\prod_i b_i(S)^{c_i - 1}},$$

  则可以证明，对函数 b_{ij} 和 b_i 优化会得到 BP 自由熵。但遗憾的是，$Q(S)$ 实际上未必对应真正的概率密度，它并不总是可归一化，因此不能应用变分界。

- 对于铁磁模型，更确切地说对于吸引性势 Ψ_{ij}，并且仅在此情形下，可以严格证明 BP 在任意图上确实给出自由熵的下界。因此对于这类模型（从而包括 RFIM!），它实际上等价于变分方法。事实上，还可以进一步证明，在零温极限下，BP 能在任意图上找到 RFIM 的基态（通过映射到线性规划）。

译注： 最后一项关于“仅在此情形”、任意图上的下界和零温 BP 基态的断言按原文保留；其精确定理假设、消息不动点选取、收敛性和算法解释应结合所引文献逐项核查，不能从上面的树上恒等式直接推出。上面的试探分布分母 $b_i(S)$ 亦照原文记号保留，需核查其自变量是否应为 S_i。

4.3 随机图上的空腔法

4.3.1 随机图

现在讨论稀疏 Erdős–Rényi（ER）随机图的基本性质。

ER 随机图是从具有 N 个顶点、M 条边的图组成的系综 $G(N, M)$ 中均匀随机抽取的。要创建这样的图，只需向空图中添加 M 条随机边。另一种做法是定义所谓的 $G(N, p)$ 系综，其中每对节点之间独立地以给定概率 $0 < c/N < 1$ 存在一条边。当 $M = c(N-1)/2$ 时，这两个系综在大 N 极限下渐近等价。常数 c 称为平均度。记节点 i 的度为 c_i，即与 i 相连的节点数。度服从均值为 c 的 Poisson 分布。另一种做法是从系综 $R(N, c)$ 中构造所谓的正则随机图，它有 N

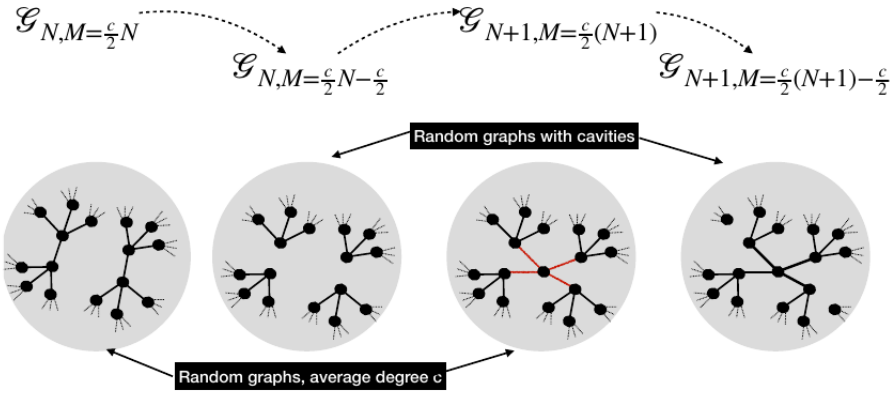


图 4.3.1: 空腔法中随机图的迭代构造。图的平均度为 c；图中 Random graphs with cavities 表示带空腔的随机图，Random graphs, average degree c 表示平均度为 c 的随机图。

个顶点，但每个顶点的度被固定为恰好 c。这意味着边数也被固定为 $M = cN/2$。

空腔方法的核心是，这类随机图在局部看起来像树，即没有经过典型节点的短环。关键点因此在于：在这个极限下，可以在局部把这些随机图视为树。该结果的直观论证如下：从一个随机位置出发并沿边移动，经过 ℓ 步将到达 c^ℓ 个位置。为了出现一个环，我们因此需要 $c^\ell \sim N$ 才能回到起始位置，这给出 $\ell \sim \log N$。**译注：**本段保留原文关于度分布和环长度的简述；有限 N 下 $G(N, c/N)$ 的度是二项分布，Poisson 形式为固定 c 时的极限。局部树状性通常是固定邻域随 $N \to \infty$ 的概率性质；上述环长度论证是启发式的，且 $c = 1$ 等情况需要特别处理。两个系综“渐近等价”的具体含义也应按所考察的事件说明。

4.3.2 空腔方法

现在让我们把熟悉的空腔法应用于一个有 N 条边、平均有 $M = cN/2$ 条边的 ER 随机图。我们将看到，这一方法如何使用与先前相同的望远镜求和技巧得到自由熵。然而这一步需要谨慎。如果天真地应用通常的 Cesàro 技巧，写成

$$Z_{N,M} = \frac{Z_{N,M}}{Z_{N-1,M-m_1}} \frac{Z_{N-1,M-m_1}}{Z_{N-2,M-m_1-m_2}} \cdots Z_{1,0},$$

那么每一步选择 m 的值时便会遇到问题。我们希望新自旋平均有 c 个邻居。这意味着每一步必须添加一个均值为 c 的 Poisson 变量 m，使新自旋具有正确的邻居数。但这也向原先的图中的 c 个自旋各添加一条边，因此平均而言，我们从 $M = cN/2$ 变为 $M' = cN/2 + c$，而实际需要的是 $M' = c(N+1)/2$。二者相差 $\Delta M = c/2$，所以需要构造图序列，使得每次添加一个与先前 m 个自旋相连的自旋时，平均移去 $m/2$ 条边。因此改写为

$$Z_{N,M} = \frac{Z_{N,M}}{Z_{N-1,M-m_1}} \frac{Z_{N-1,M-m_1}}{Z_{N-1,M-m_1+m_2/2}} \frac{Z_{N-1,M-m_1+m_2/2}}{Z_{N-2,M-m_1+m_1'/2-m_2}} \cdots Z_{1,0}.$$

译注：本节开头原文同时称 N 和 M 为边数；结合前文及后续构造，N 的含义需核查是否为节点数。上述望远镜乘积的下标、随机边数和半整数写法也依原文保留，严格有限图构造与配对方式需另行说明。

具体而言，这意味着必须对下列项应用 Cesàro 定理来计算自由熵：

$$\begin{aligned} A_N &= \log \frac{Z_{N,M=Nc/2}}{Z_{N-1,M-c}} \frac{Z_{N-1,M-c}}{Z_{N-1,M-c+c/2}} \\ &= \log \frac{Z_{N,M=Nc/2}}{Z_{N-1,M-c}} - \log \frac{Z_{N-1,M-c+c/2}}{Z_{N-1,M-c}}. \end{aligned}$$

于是得到

$$\lim_{N,M\to\infty} \mathbb{E} \frac{1}{N} \log Z_N = \lim_{N\to\infty} \mathbb{E} A_N = \lim_{N\to\infty} \mathbb{E}\Phi_N^{(\text{site})} - \lim_{N\to\infty} \mathbb{E}\Phi_N^{(\text{link})}.$$

因此，我们需要计算两项来求自由熵，它们对应图 4.3.1 所示的图上两步迭代：

1. 第一项对应于向图中添加一个自旋、并将它连接到带 c 个空腔的 c 个自旋时自由熵的变化。

2. 第二项对应于向图中添加 $c/2$ 条边、将带空腔的 c 个自旋成对连接时自由熵的变化。

这与我们在树上找到的结果完全对应！事实上，在第 4.2.1 节中，我们看到有 N 个位置项减去 $M = cN/2$ 个边项。这一构造给出与树相同的答案，令人放心。

从数学上看，这两个自由熵改变量可表示为

$$\begin{aligned}\Phi_N^{(\mathrm{site})} &= \mathbb{E}\log\left\langle \sum_{S_0} e^{\beta h_0 S_0 + \beta J \sum_{i\in\partial 0} S_0 S_i} \right\rangle_{N-1,M-c} \\ &= \mathbb{E}\log\left\langle 2\cosh\left(\beta h_0 + \beta J \sum_{i\in\partial 0} S_i\right)\right\rangle_{N-1,M-c}, \\ \Phi_N^{(\mathrm{link})} &= \mathbb{E}\log\left\langle \prod_{(ij)} e^{\beta J S_i S_j}\right\rangle_{N-1,M-c} = \frac{c}{2}\mathbb{E}\log\langle e^{\beta J S_i S_j}\rangle_{N-1,M-1}.\end{aligned}$$

有趣的是，这两个方程都依赖于图中的空腔磁化强度联合分布，因此可以写成

$$\begin{aligned}\Phi^{(\mathrm{site})} &= \mathbb{E}\int dP_e(d)\int \prod_{i=1}^{d} dm_i\, Q^c(\{m_i\})\log\left\langle 2\cosh\left(\beta h_0 + \beta J\sum_{i\in\partial 0} S_i\right)\right\rangle_{\{m_i\}}, \\ \Phi^{(\mathrm{link})} &= \mathbb{E}\frac{c}{2}\int dm_1\, Q(m_1,m_2)\log\langle e^{\beta J S_i S_j}\rangle_{\{m_1,m_2\}},\end{aligned}$$

其中 $P_e(d)$ 是剩余度概率。对连接度固定为 c 的正则图，$P_e(d) = \delta(d-(c-1))$；而对 Erdős–Rényi 随机图，有趣的是再次得到 $P_e(d) = P(d)$！见习题部分。**译注：** 边项联合分布积分在原文只写 dm_1 而被积函数仍依赖 m_2；等号中的多边平均拆分、剩余度与添加新节点时度分布的角色，也需核查独立性、极限和采样约定。此处保留原式。

在物理学中使用的严格程度下，可以进一步简化这些公式！首先假设空腔场的分布独立于无序，并收敛到一个极限分布。其次，关键是现在假设这些空腔边缘分布可以分解！这是有道理的：不同空腔 $\{m_i\}$ 在图中相距很远。如果我们不恰好处在临界点（相变点），则关联并非无限程。在这种情况下，公式只依赖于单点分布 $Q^c(m)$，因此写出

$$\begin{aligned}\Phi^{(\mathrm{site})} &= \int dP_e(d)\int \prod_{i=1}^{d} dm_i\, Q^c(m_i)\log\left\langle 2\cosh\left(\beta h_0 + \beta J\sum_{i\in\partial 0} S_i\right)\right\rangle_{\{m_i\}}, \\ \Phi^{(\mathrm{link})} &= \frac{c}{2}\int dm_1\, Q(m_1)\, dm_2\, Q(m_2)\log\langle e^{\beta J S_i S_j}\rangle_{\{m_1,m_2\}}.\end{aligned}$$

因此，我们的任务是寻找渐近分布 $Q(m)$。在物理学使用的严格程度下，这很容易做到。我们显然假设 $Q(m)$ 唯一，且不依赖于无序的实现（这并非如此简单）。接着注意到，空腔场分布必须满足如下递推：

$$Q_{N+1}^c(m) = \int dh_0\, P(h_0)\int dP_e(d)\prod_{i=1}^{d}\int dm_i\, Q_{N+1}^c(m_i)\,\delta\big(m - f_{\mathrm{BP}}(\{m_i\},h_0)\big),$$

其中

$$f_{\mathrm{BP}}(\{m_i\},h_0) = \tanh\left(\beta h_0 + \sum_i \operatorname{atanh}(m_i\tanh(\beta J))\right).$$

显然，一旦找到不动点，就能计算总磁化强度的分布，其表达式几乎完全相同，但现在必须使用真实的邻居数分布：

$$Q(m)=\int dh_0\,P(h_0)\int dP_e(d)\prod_{i=1}^{d}\int dm_i\,Q^c(m_i)\,\delta\big(m-f_{\mathrm{BP}}(\{m_i\},h_0)\big).$$

译注： 原文称后一式使用真实邻居数分布，却仍写 $P_e(d)$；对一般图系综，节点度分布与剩余度分布并不相同，须区分 $P(d)$ 和 $P_e(d)$。上一个写作 Q^c_{N+1} 的“递推”两边同为 $N+1$，其有限尺寸指标亦需核查。源式均保留。

原文待补条目。 原文此处仅列出以下待补提纲：

1. 解释群体动力学。
2. 指出自由能与图上的结果相同，并给出“图”与“群体”的对应字典。
3. 增加关于正则图与随机图以及剩余度的讨论。

4.3.3 有环信念传播与空腔方法的关系

原文待补条目：

- 树状等……
- 单个图与群体！

4.3.4 我们能证明它吗？

我们可以试一试!!! 首先 $Q^c(m)$ 并不明显是自平均的，但肯定有

$$\begin{aligned}\Phi\le\max_{Q^c(m)}&\int dP_e(d)\prod_{i=1}^{d}\int dm_i\,Q^c(\{m_i\})\log\left\langle 2\cosh\left(\beta h_0+\beta J\sum_{i\in\partial 0}S_i\right)\right\rangle_{\{m\}}\\&-\frac{c}{2}\int dm_1\,Q^c(\{m_1\})\,dm_2\,Q^c(\{m_2\})\log\langle e^{\beta JJS_iS_j}\rangle_{m_1,m_2}.\end{aligned}$$

可以证明，取极值会使 $Q(m)$ 成为空腔递推的解。这意味着我们得到了一个界！如果找到了满足该方程的分布 $Q(m)$（或实际上找到了所有这样的分布），就有一个界。

能否轻易得到反向的界？遗憾的是不能。问题在于，对一个给定实例，BP 不是变分方法，因此我们不能使用平均场技巧！幸运的是，可以严格证明，对任意铁磁模型，BP 确实给出自由熵的下界。

与完全连接模型的结果比较也很有启发。事实上，如果 $Q(m)$ 变成一个 delta 分布（我们预期当 c 增大时会如此），取 $J=1/N$ 得到

$$\Phi\le\max_m\mathbb{E}_h\log 2\cosh(\beta h+\beta m)-\frac{N}{2}\log e^{\beta m^2/N}=\mathbb{E}_h\log 2\cosh(\beta h+\beta m)-\beta\frac{m^2}{2},$$

这正是我们在完全连接极限下得到的结果！**译注：** 第一式中指数的 JJ、联合分布 $Q^c(\{m_i\})$ 的用法及末式极大值的作用范围均按原文保留；上界及相反方向的 BP 下界需要明确可容许分布、无序平均、图系综、固定点和极限条件。仅凭本段公式不能认证所声称的严格证明。

4.3.5 何时预期这一方法有效？

我们何时预期信念传播是正确的？如前所述，随机图在局部是树状的：直到任何有限距离它们都是树。进一步假设我们处于纯热力学态，就预期关联为短程，因此在足够大的系统中，长度为 $O(\log N)$ 的环应当无关紧要，而这些方程应给出该模型的正确描述。

显然，这必须是描述顺磁相系统的好方法，甚至也适用于发生铁磁相变的系统（此时应当预期迭代有两个不同不动点）。然而，这些方程也可能存在大量不动点：如何处理这种情况？它们是否都应当对应某个纯态？幸运的是，我们没有这样的担忧，因为刚刚描述的情况正是在发生玻璃相变时出现的。此时需要像 Mézard、Parisi 和 Virasoro 那样，将空腔法与所谓“副本对称性破缺”方法结合使用。

文献说明。 空腔方法受到 Bethe (1935) 和 Peierls (1936) 原始思想的启发，并被详细用于研究铁磁性（Weiss，1948）。信念传播最早出现在计算机科学的 Shannon 纠错背景中（Gallager，1962），随后在许多不同背景下被重新发现。“信念传播”这一名称尤其源于 Pearl (1982)。有环信念传播与 Bethe“空腔”方法的深刻关系在 21 世纪初被讨论，例如 Opper 和 Saad (2001)、Wainwright 和 Jordan (2008)；Yedidia 等 (2003) 的工作尤其有影响。本章关于随机图空腔法的构造遵循 Mézard 和 Parisi (2001, 2003) 的经典论文。在铁磁模型（更一般地说吸引性模型）情形下，有环信念传播在任意图上给出真实配分函数的下界，是一个深刻而非平凡的结果：Willsky 等 (2007) 使用 Chertkov 和 Chernyak (2006) 的环计算部分证明了这一点，Ruozzi (2012) 给出完整证明。Chertkov (2008) 展示了信念传播如何在零温找到 RFIM 的基态。最后，Saade 等 (2017) 证明空腔方法给出临界温度的严格上界。

4.4 习题

习题 4.1：Erdős–Rényi 图中的剩余度

考虑一个有 N 个节点、M 条边的 Erdős–Rényi 随机图，其渐近区域为 $N \to \infty$，平均度为 $c = 2M/N$。

1. 对一个给定节点，它与另一个给定节点（比如 j）相连的概率 p 是多少？由于它有 $N-1$ 个可能的邻居，证明每个节点的邻居数的概率分布满足

$$\mathbb{P}(d = k) = \frac{c^k e^{-c}}{k!}. \tag{4.10}$$

   在空腔法中，我们经常还关心剩余度分布：即给定一个具有邻居 j 的位置 i，它的额外邻居数 d 的分布是什么？

2. 说明为什么先找到一条边 (ij) 再查看 i，等价于以正比于节点邻居数的概率对所有节点抽样：

$$\mathbb{P}_i = \frac{d_i}{c}. \tag{4.11}$$

3. 最后证明，当以 d_i/c 的概率选择每个位置时，具有 $k+1$ 个邻居的概率分布为

$$\mathbb{P}(d = k+1) = \frac{c^{k+1} e^{-c}}{k+1!} \frac{k+1}{c}, \tag{4.12}$$

因而剩余度概率分布为

$$\mathbb{P}^e(d=k)=\frac{c^k e^{-c}}{k!}. \tag{4.13}$$

译注：式 (4.11) 的 d_i/c 一般是相对于均匀节点抽样的权重，而不是在 N 个节点上归一化的单节点概率；具体抽样概率需包含相应归一化因子。式 (4.12) 的分母按原文写为 $k+1!$，若要得到下式的 Poisson 结果，应核查原文是否意为 $(k+1)!$。原文的重复小问编号已按题目顺序排版。

习题 4.2：正则随机图上的随机场 Ising 模型

我们已看到 RFIM 的 BP 更新方程为

$$f_{\mathrm{BP}}(\{m_i\},h_0)=\tanh\left(\beta h_0+\sum_i \operatorname{atanh}(m_i\tanh(\beta J))\right), \tag{4.14}$$

而空腔场分布满足（针对固定连接度 $c-1$ 的随机图）

$$Q^{\mathrm{cav}\cdot}(m)=\int dh_0\,\mathcal{N}(h_0;0,\Delta)\prod_{i=1}^{c-1}\int dm_i\,Q^{\mathrm{cav}}(m_i)\,\delta\big(m-f_{\mathrm{BP}}(\{m_i\},h_0)\big). \tag{4.15}$$

在实践中可以用*群体动力学*方法求解：用 $\mathcal{N}_{\mathrm{pop}}$ 个元素组成的群体表示 $Q^{\mathrm{cav}\cdot}(m)$。在这种情况下，我们在形式上迭代一个元素的集合或池。从 $Q^{\mathrm{cav}\cdot}_{t=0}(m)=[m_1,m_2,m_3,\ldots,m_{\mathcal{N}_{\mathrm{pop}}}]$ 出发，例如取所有 $m=1$ 或随机初始条件，按如下步骤迭代：

- 重复 T 步；
- 对所有 $i=1\to\mathcal{N}_{\mathrm{pop}}$：
- 抽取随机的 $h_0\sim\mathcal{N}(0,\Delta)$，并从 $Q^{\mathrm{cav}\cdot}_t$ 中随机抽取 $c-1$ 个 $\{m_i\}$；
- 计算 $m^{\mathrm{new}}=f_{\mathrm{BP}}(\{m_i\},h_0)$；
- 将 m 赋给新群体的第 i 个元素：$Q_{t+1,i}=m^{\mathrm{new}}$。

如果 $\mathcal{N}_{\mathrm{pop}}$ 足够大（比如 10^5），那么这是对真实群体密度的良好近似；如果 T 足够大，我们应已收敛到不动点。一旦完成，便可按如下方式通过计算真正的边缘分布来计算平均磁化强度：

- 令 $\overline{m}=0$；
- 重复 $\mathcal{N}$ 步；
- 从 $Q^{\mathrm{cav}\cdot}_{\mathrm{eq}}$ 中随机抽取 c 个 $\{m_i\}$；
- 这一次使用 c 个值计算 $m^{\mathrm{new}}=f_{\mathrm{BP}}(\{m_i\},h_0)$；
- 令 $\overline{m}=\overline{m}+m^{\mathrm{new}}/\mathcal{N}_{\mathrm{pop}}$。

译注：第二段平均磁化强度伪代码按原文保留，但未再次说明 h_0 的抽样；其循环次数写为 $\mathcal{N}$，累加分母却为 $\mathcal{N}_{\mathrm{pop}}$。若二者不同，归一化需另行核查。

1. 考虑连接度 $c = 4$ 的正则随机图上的 RFIM。在无无序场（$\Delta = 0$）时解析计算 β 中的相变点 β_c。

2. 实现群体动力学，并数值求出 $\overline{m}(\beta, \Delta)$ 变为非零时的相变点。绘制 (β, Δ) 相图，区分 $\overline{m} = 0$ 与 $\overline{m} \neq 0$ 的相。

3. 现在专门考虑低温（最终为零温）极限。使用变量变换 $m_i = \tanh(\beta \widetilde{h}_i)$，证明当 $\beta \to \infty$ 时迭代有如下极限：

$$\widetilde{h}^{\text{new}} = \lim_{\beta \to \infty} \frac{1}{\beta} \operatorname{atanh} f_{\text{BP}}(\{m_i\}, h_0) = h_0 + \sum_i \phi(\widetilde{h}_i), \tag{4.16}$$

$$\phi(x) = \begin{cases} x, & |x| < 1, \\ \operatorname{sign}(x), & |x| > 1. \end{cases} \tag{4.17}$$

4. 使用这一方程执行零温群体动力学，并计算出现非零磁化强度时 Δ 的临界值。

译注： 式 (4.17) 的阈值 1 按原文保留；式 (4.14) 中耦合为一般 J，因此该极限是否隐含 $J = 1$ 需核查。端点 $|x| = 1$ 亦未在原式给出。

5 稀疏图与局部树状图模型

在我的树旁，我曾快乐地生活，

我本不该远离我的树。

《Auprès de mon arbre》，Georges Brassens，1955

前几章的一个共同主题是研究 Boltzmann–Gibbs 分布：

$$P_{N,\beta}(S = s) = \frac{e^{-\beta \mathcal{H}(s)}}{Z_N(\beta)}.$$

这是随机变量 $S_1, \ldots, S_N$ 的联合概率分布，通过能量函数 $\mathcal{H}$ 定义。在迄今见到的两个例子中，能量函数由两部分构成：耦合不同随机变量的相互作用项，以及分别作用于每个随机变量的势项。例如，对 Curie–Weiss 模型，

$$\mathcal{H}_{N,h}(s) = \underbrace{-\frac{1}{2N} \sum_{i,j=1}^{N} s_i s_j}_{\text{相互作用}} \underbrace{-h \sum_{i=1}^{N} s_i}_{\text{势}}.$$

注意，正是相互作用项使随机变量之间产生关联：若它为零，Gibbs–Boltzmann 分布就会因子化，我们只需独立研究每个变量便能完全刻画系统。正是相互作用项使问题真正具有多维性。

在 Curie–Weiss 模型和 RFIM 中，相互作用项是二次的：它将随机变量两两耦合。在后续各章，我们将研究许多其他 Gibbs–Boltzmann 分布例子，它们由不同类型的变量、势和相互作用项定义。因此，引入一种思考和表示多维概率分布的非常一般的方法将很有用。这就是本章主题。

5.1 图模型

为了继续研究概率模型，我们引入称为图模型的工具，它为我们思考广泛的概率分布提供整洁而非常一般的方式。图模型是表示变量之间关系或关联的一种方法。

本节给出基本定义，并介绍几个稍后将在课程中更详细研究的例子。

5.1.1 图

一个无向图 $G(V,E)$ 定义为：

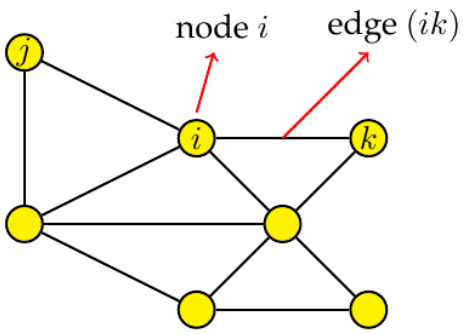
- 节点集合 V，以 $i \in V$ 为指标；
- 边集合 E，以一对节点 $(ij) \in E$ 为指标。

记 $|S|$ 为集合 S 的大小。本节将总节点数记为 $|V| = N$，总边数记为 $|E| = M$。图 $G(V,E)$ 的邻接矩阵是一个对称的 $N \times N$ 二元矩阵 $A \in \{0,1\}^{N\times N}$，其元素为

$$A_{ij} =: \begin{cases} 1, & (ij) \in E, \\ 0, & (ij) \notin E. \end{cases}$$

我们用 ∂ 表示邻域算符，即 $\partial i := \{j \in V \mid (ij) \in E\}$ 是节点 i 的邻居集合。对固定节点 $i \in V$，定义其度为 $d_i = |\partial i|$，即 i 的邻居总数。注意 d_i 很容易从邻接矩阵 A 得到：

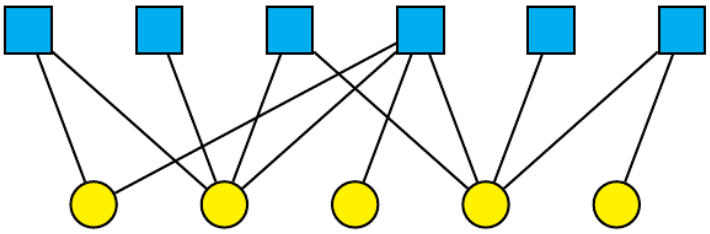
$$d_i = \sum_{j=1}^{N} A_{ij} = \sum_{j=1}^{N} \mathbf{1}_{(ij)\in E}.$$



图中 node i 和 edge (ik) 分别表示节点 i 与边 (ik)。

5.1.2 因子图

- 因子图是具有“圆形”和“方形”两类节点的图：圆形节点是变量节点，以 $i, j, k, \ldots$ 为指标；方形节点是因子节点，以 $a, b, c, \ldots$ 为指标。
- 因子图是二部图：只有“圆形”与“方形”节点之间的边，不存在“圆形”之间或“方形”之间的边。



$$\partial i := \{a \mid (ia) \in E\}, \qquad |\partial i| = d_i, \qquad \forall i \in \{1, \dots, N\},$$
$$\partial a := \{i \mid (ia) \in E\}, \qquad |\partial a| = d_a, \qquad \forall a \in \{1, \dots, M\}.$$

- 每个变量节点 i 表示取值于 Λ 的随机变量 s_i。
- 每个因子节点 a 表示一个非负函数 $f_a(\{s_i\}_{i\in\partial a})$。

图模型表示变量 $\{s_i\}_{i=1}^N$ 上的联合概率分布：

$$P(\{s_i\}_{i=1}^N) =: \frac{1}{Z_N} \prod_{a=1}^M f_a(\{s_j\}_{j\in\partial a}),$$

其中 Z_N 为归一化常数：

$$Z_N =: \sum_{\{s_i\}_{i=1}^N} \prod_{a=1}^M f_a(\{s_j\}_{j\in\partial a}).$$

本讲义将广泛使用图模型作为语言，表示优化、推断和学习问题中出现的概率分布。我们将研究各种 f_a、Λ 和图模型。先给出几个例子。

例 1（物理：自旋玻璃）。 考虑作为相互作用图的 $G(V, E)$，例如具有 $N = 10^{23}$ 个节点的三维立方晶格。节点可以代表 N 个 Ising 自旋 $s_i \in \Lambda = \{-1, +1\}$。在统计物理中，系统通常由称为 Hamiltonian 的能量函数定义。可以把 Hamiltonian 看作一个简单的成本函数，其值越低越好。自旋玻璃的 Hamiltonian 为

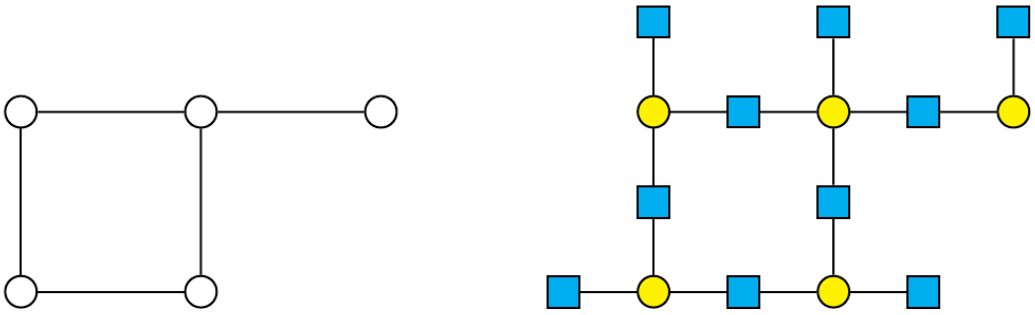
$$\mathcal{H}(\{s_i\}_{i=1}^N) = -\sum_{(ij)\in E} J_{ij} s_i s_j - \sum_i h_i s_i,$$

其中 $J_{ij} \in \mathbb{R}$ 是相互作用，$h_i \in \mathbb{R}$ 是磁场。与 Hamiltonian 对应，我们考虑定义如下的 Boltzmann 概率分布：

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z_N} e^{-\beta \mathcal{H}(\{s_i\}_{i=1}^N)} = \frac{1}{Z_N} \prod_{i=1}^N e^{\beta h_i s_i} \prod_{(ij)\in E} e^{\beta J_{ij} s_i s_j},$$

其中归一化常数 $Z_N = \sum_{\{s_i\}_{i=1}^N} e^{-\beta \mathcal{H}(\{s_i\}_{i=1}^N)}$ 称为配分函数。

定义在图 $G(V, E)$ 上的自旋玻璃及其对应图模型分别画在下图左、右两侧。



该图模型有：

- 对每个节点 i，一个与磁场 h_i 对应的因子节点 $f_i(s_i) = e^{\beta h_i s_i}$；
- 对每条边 $(ij) \in E$，一个与相互作用 J_{ij} 对应的因子节点 $f_{(ij)}(s_i, s_j) = e^{\beta J_{ij} s_i s_j}$。

例 2（组合优化：图着色）。 考虑一个图 $G(V, E)$ 和 q 种颜色：红、蓝、绿、黄，等等，直至黑色，记为 $s_i \in \{1, 2, \dots, q\}$。图着色问题要求为每个节点分配颜色，使相邻节点的颜色不同。

图 5.1.1 展示了对应（平面）图的一个合法四色着色。注意，同一图也可以只用三种颜色着色，但不能只用两种颜色。为了用图模型语言建立图着色问题，将图 $G(V, E)$ 的合法着色数写成



图 5.1.1: 地图着色与图着色如何对应的示意。

$$Z_N = \sum_{\{s_i\}_{i=1}^N} \prod_{(ij)\in E} (1 - \delta_{s_i, s_j}).$$

当且仅当 $Z_N \geq 1$ 时图可着色；此时还可以定义所有合法着色上的均匀概率测度：

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z_N} \prod_{(ij)\in E} (1 - \delta_{s_i, s_j}).$$

我们也可以软化对颜色的限制，引入更一般的概率分布：

$$P(\{s_i\}_{i=1}^N, \beta) = \frac{1}{Z_N(\beta)} \prod_{(ij)\in E} e^{-\beta \delta_{s_i, s_j}}.$$

当 $\beta \nearrow \infty$ 时恢复严格约束的情形。此时图着色问题的图模型对应于每条边 (ij) 上形式为 $f_{(ij)}(s_i, s_k) = e^{-\beta \delta_{s_i, s_j}}$ 的因子节点。**译注：**最后一个因子函数的第二个自变量 s_k 与右侧的 s_j 不一致；这里保留原文，需核查记号。

例 3（统计推断：无监督学习）。 可用图模型直接表示的概率分布也自然出现在统计推断中。我们可以给出随机块模型的例子，它是网络社区发现中常用的模型。在 SBM 中，N 个节点被分成 q 个群组，节点 i 的群组记为 $s_i^* \in \{1,2,\dots,q\}$，其中 $i=1,\dots,N$。节点 i 以概率 $n_a \geq 0$（即预期群组大小所占比例）分配到群组 $s_i^* = a$，其中 $\sum_{a=1}^{q} n_a = 1$。节点对之间以对应于其群组归属的概率连接。具体地，

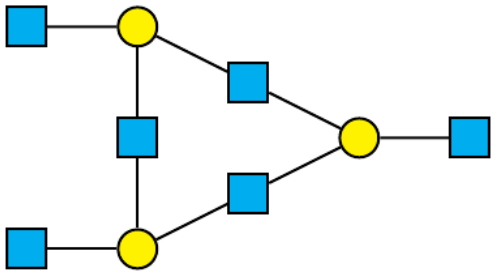
$$\begin{cases} P((ij) \in E \mid s_i^*, s_j^*) = p_{s_i^* s_j^*}, \\ P((ij) \notin E \mid s_i^*, s_j^*) = 1 - p_{s_i^* s_j^*} \end{cases} \quad \Longrightarrow \quad G(V,E) \text{ 与 } A_{ij},$$

其中 p_{ab} 构成对称的 $q \times q$ 矩阵。

社区发现的问题是：给定边 A_{ij} 和参数 $\theta = (n_a, p_{ab}, q)$，能否恢复所有 $i=1,\dots,N$ 的 s_i^*？一个要求较低的挑战是寻找估计量 $\widehat{s}_i$，使 $\widehat{s}_i = s_i^*$ 对尽可能多的节点 i 成立。

我们采用贝叶斯推断框架。关于 s_i^* 的所有信息都包含在后验概率分布中：[6]

$$\begin{aligned} P(\{s_i\}_{i=1}^N \mid A, \theta) &= \frac{1}{Z_N(A,\theta)} P(A \mid \{s_i\}_{i=1}^N, \theta) P(\{s_i\}_{i=1}^N \mid \theta) \\ &= \frac{1}{Z_N(A,\theta)} \prod_{i<j} \left[(1 - p_{s_i,s_j})^{1-A_{ij}} p_{s_i,s_j}^{A_{ij}} \right] \prod_{i=1}^{N} n_{s_i}. \end{aligned}$$



对应的图模型对每个变量（场）有一个因子节点，对每对节点（相互作用）有一个因子节点。事实上，我们注意到，即使没有边的节点对（即 $A_{ij}=0$）也有因子节点 $f_{ij}(s_i,s_j) = 1 - p_{s_i,s_j}$。本课程将相当广泛地研究这一后验分布。

例 4（广义线性模型）。 设 n 为数据样本数，d 为数据维数。样本记为 $X_\mu \in \mathbb{R}^d$，标签为 $y_\mu \in \{-1,+1\}$（猫 / 狗），其中 $\mu = 1,\dots,n$。广义线性回归由以下形式的损失函数的最小化表述：

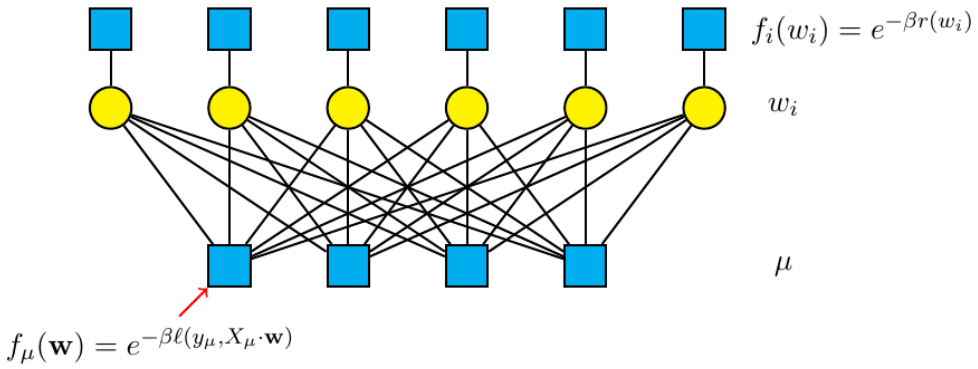
$$\mathcal{L}(\mathbf{w}) = \sum_{\mu=1}^{n} \ell(y_\mu, X_\mu \cdot \mathbf{w}) + \sum_{i=1}^{d} r(w_i).$$

损失最小化问题随后可以被视为以下概率测度的 $\beta \to \infty$ 极限：

$$P(\mathbf{w}) = \frac{1}{Z_N(X,y,\beta)} e^{-\beta \mathcal{L}(\mathbf{w})} = \frac{1}{Z_N(X,y,\beta)} \prod_{i=1}^{d} e^{-\beta r(w_i)} \prod_{\mu=1}^{n} e^{-\beta \ell(y_\mu, X_\mu \cdot \mathbf{w})}.$$

对应的图模型如下：

[6] 注意，后验分布中的 s_i 只是一个哑变量，即函数的自变量。



5.1.3 因子图的一些性质与用途

如上述例子所示，因子通常分为两类：(i) 只关联一个变量的因子节点，例如自旋玻璃中的磁场、广义线性回归中的正则化项或随机块模型中的先验；(ii) 与变量间相互作用有关的因子节点。为方便起见，我们分别处理这两类因子，记前者为 $g_i(s_i)$，后者为 $f_a(\{s_i\}_{i\in\partial a})$。第 (i) 类因子节点用 $i, j, k, l, \ldots$ 作指标，第 (ii) 类因子用 $a, b, c, d, \ldots$ 作指标。在此记号下，所关心的概率分布为

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z} \prod_{i=1}^N g_i(s_i) \prod_{a=1}^M f_a(\{s_i\}_{i\in\partial a}).$$

正如前面已经看到、并将在本课程中进一步看到的，感兴趣的量可以从归一化常数的值中提取；物理学中称其为配分函数，其表达式为

$$Z = \sum_{\{s_i\}_{i=1}^N} \prod_{i=1}^N g_i(s_i) \prod_{a=1}^M f_a(\{s_i\}_{i\in\partial a}).$$

我们尤其关注自由熵 $N\Phi = \log Z$ 的值。另一个感兴趣的量是各变量的边缘分布，它与物理学中的局域磁化有关，定义为

$$\mu_i(s_i) = \sum_{\substack{\{s_j\}_{j=1}^N \\ j\neq i}} P(\{s_j\}_{j=1}^N).$$

对于大系统，计算配分函数与边缘分布的困难在于需要对项数随 N 指数增长的和求值。从计算复杂性的角度看，我们不知道能够对一般图模型精确计算这些和的多项式时间算法。在本讲余下部分，我们将讨论能够精确计算边缘分布和自由熵的情况，精确程度达到系统大小 N 的主导阶。

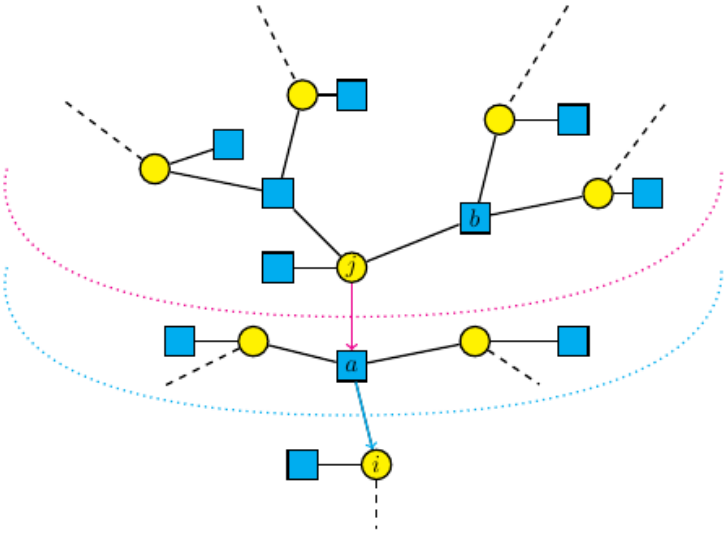
一类可以精确计算边缘分布和自由熵的特殊图模型是树形图模型，即不含回路的图。下一节将说明如何处理这一情况。随后我们将说明，对于局部看起来像树的图，即经过典型节点的最短回路很长的图，可以通过谨慎使用类树近似求解问题。这类近似适用于与随机稀疏图对应的图模型，即当系统大小 N 增长时平均度保持为常数的图。我们还将看到，在大系统极限下，一系列定义在稠密连接因子图上的问题也可以精确求解。

5.2 信念传播与 Bethe 自由能

5.2.1 在树形图模型上推导信念传播

我们首先计算树形图模型的配分函数 Z 与边缘分布 $\mu_i(s_i)$。回顾所考虑的概率分布为

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z}\prod_{i=1}^{N} g_i(s_i)\prod_{a=1}^{M} f_a(\{s_i\}_{i\in\partial a}).$$



为了表达边缘分布和配分函数，我们对每条 $(ia)\in E$ 定义辅助配分函数：

$$R_{s_j}^{j\to a} = g_j(s_j)\sum_{\{s_k\}_{k\text{ 在}j\text{ 上方}}}\prod_{k\text{ 在}j\text{ 上方}} g_k(s_k)\prod_{b\text{ 在}j\text{ 上方}} f_b(\{s_l\}_{l\in\partial b}),$$

$$V_{s_i}^{a\to i} = \sum_{\{s_j\}_{j\text{ 在}a\text{ 上方}}} f_a(\{s_k\}_{k\in\partial a})\prod_{j\text{ 在}a\text{ 上方}} g_j(s_j)\prod_{b\text{ 在}a\text{ 上方}} f_b(\{s_k\}_{k\in\partial b}).$$

这些量的含义可从上图理解：$R_{s_j}^{j\to a}$ 是红色虚线上方部分系统的配分函数，其中变量节点 j 限定为取值 s_j；类似地，$V_{s_i}^{a\to i}$ 是蓝色虚线上方子系统的配分函数，其中变量节点 i 限定为取值 s_i。[7]

由于图模型是一棵树，即没有回路，将变量 j 限定为 s_j 后，j 上方的各分支相互独立。因此可按所属分支拆开对变量的求和，得到

$$\begin{aligned} R_{s_j}^{j\to a} &= g_j(s_j)\prod_{b\in\partial j\setminus a}\left[\sum_{\{s_k\}_{k\text{ 在}b\text{ 上方}}} f_b(\{s_k\}_{k\in\partial b})\prod_{k\text{ 在}b\text{ 上方}} g_k(s_k)\prod_{c\text{ 在}b\text{ 上方}} f_c(\{s_l\}_{l\in\partial c})\right] \\ &= g_j(s_j)\prod_{b\in\partial j\setminus a} V_{s_j}^{b\to j}, \end{aligned}$$

其中识别并使用了 $V_{s_j}^{b\to j}$ 的定义。类似地，把 $V_{s_i}^{a\to i}$ 中的和按因子节点 a 上方树的各分支拆开，得到

$$V_{s_i}^{a\to i} = \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i}\left[\sum_{\{s_k\}_{k\text{ 在}j\text{ 上方}}} g_j(s_j)\prod_{k\text{ 在}j\text{ 上方}} g_k(s_k)\prod_{b\text{ 在}j\text{ 上方}} f_b(\{s_l\}_{l\in\partial b})\right]$$

[7]注意，由于 $i\in\partial a$，s_i 出现在 f_a 的自变量中。

$$= \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} R_{s_j}^{j\to a}. \tag{*}$$

若从树叶开始，即从只属于一个因子 a 的变量节点开始，定义给出 $R_{s_j}^{j\to a} = g_j(s_j)$。结合上述关系，就可以递归地汇集各分支的贡献，并计算以节点 j 为根的树形图模型的总配分函数：

$$Z = \sum_{s_j} g_j(s_j) \prod_{b\in\partial j} V_{s_j}^{b\to j}.$$

这一值不依赖于所选择的根节点，因为无论选哪个根，配分函数的所有贡献都被计入。

配分函数通常按 $\exp(cN)$ 缩放，即随系统大小呈指数增长（只因它是指数多项之和），因而数值巨大。处理上述受限配分函数 R 和 V 的一种更方便的方法是定义消息

$$\begin{aligned}
\chi_{s_j}^{j\to a} &:= \frac{R_{s_j}^{j\to a}}{\sum_s R_s^{j\to a}}, && \sum_s \chi_s^{j\to a} = 1, \quad \forall (ja)\in E,\\
\psi_{s_i}^{a\to i} &:= \frac{V_{s_i}^{a\to i}}{\sum_s V_s^{a\to i}}, && \sum_s \psi_s^{a\to i} = 1, \quad \forall (ia)\in E.
\end{aligned} \tag{**}$$

我们把 $\chi_{s_j}^{j\to a}$ 称为从变量 j 发往因子 a 的消息，并将其解释为仅考虑红色虚线上方部分的受限系统中，变量 j 取值 s_j 的概率。类似地，$\psi_{s_i}^{a\to i}$ 称为从因子 a 发往变量 i 的消息，解释为仅考虑蓝色虚线上方部分的系统中变量 i 取值 s_i 的概率。利用这些定义，我们将上述递推关系改写为

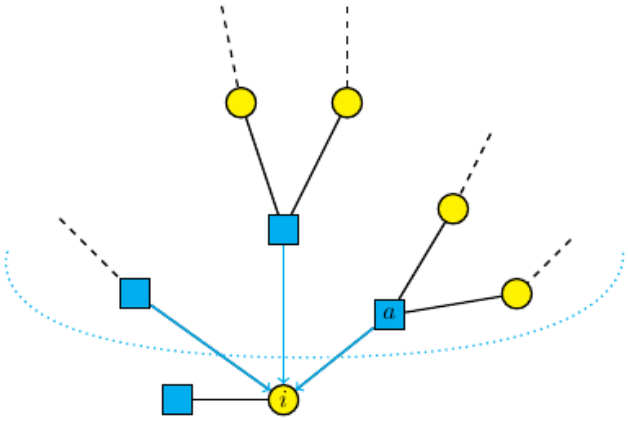
$$\begin{aligned}
\chi_{s_j}^{j\to a} &= \frac{g_j(s_j)\prod_{b\in\partial j\setminus a} V_{s_j}^{b\to j}}{\sum_s g_j(s)\prod_{b\in\partial j\setminus a} V_s^{b\to j}} \times \frac{\prod_{b\in\partial j\setminus a}\sum_{s'} V_{s'}^{b\to j}}{\prod_{b\in\partial j\setminus a}\sum_{s''} V_{s''}^{b\to j}}\\
&= \frac{g_j(s_j)\prod_{b\in\partial j\setminus a} \frac{V_{s_j}^{b\to j}}{\sum_{s''} V_{s''}^{b\to j}}}{\sum_s g_j(s)\prod_{b\in\partial j\setminus a} \frac{V_s^{b\to j}}{\sum_{s'} V_{s'}^{b\to j}}}\\
&= \frac{g_j(s_j)\prod_{b\in\partial j\setminus a} \psi_{s_j}^{b\to j}}{\sum_s g_j(s)\prod_{b\in\partial j\setminus a} \psi_s^{b\to j}} = \frac{1}{Z^{j\to a}} g_j(s_j) \prod_{b\in\partial j\setminus a} \psi_{s_j}^{b\to j},\\
Z^{j\to a} &:= \sum_s g_j(s) \prod_{b\in\partial j\setminus a} \psi_s^{b\to j}.
\end{aligned}$$

同理，

$$\begin{aligned}
\psi_{s_i}^{a\to i} &= \frac{\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} R_{s_j}^{j\to a}}{\sum_{s_i}\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} R_{s_j}^{j\to a}} \times \underbrace{\frac{\prod_{j\in\partial a\setminus i}\sum_{s'_j} R_{s'_j}^{j\to a}}{\prod_{j\in\partial a\setminus i}\sum_{s''_j} R_{s''_j}^{j\to a}}}_{=1}\\
&= \frac{\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} \frac{R_{s_j}^{j\to a}}{\sum_{s''_j} R_{s''_j}^{j\to a}}}{\sum_{s_i}\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} \frac{R_{s_j}^{j\to a}}{\sum_{s'_j} R_{s'_j}^{j\to a}}}\\
&= \frac{\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}}{\sum_{s_i}\sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}}\\
&= \frac{1}{Z^{a\to i}} \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a},
\end{aligned}$$

$$Z^{a\to i} := \sum_{s_i} \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}$$
$$= \sum_{\{s_j\}_{j\in\partial a}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}.$$

以上得到的消息 χ 与 ψ 的自洽方程称为信念传播方程。



现在我们希望以可推广到非树形因子图的方式表示边缘分布 $\mu_i(s_i)$ 和配分函数 Z。为此，首先仍在树形因子图假设下写出边缘分布

$$\mu_i(s_i) = \frac{1}{Z} g_i(s_i) \prod_{a\in\partial i} V_{s_i}^{a\to i} = \frac{g_i(s_i)\prod_{a\in\partial i} V_{s_i}^{a\to i}}{\sum_s g_i(s)\prod_{a\in\partial i} V_s^{a\to i}} \times \underbrace{\frac{\prod_{a\in\partial i}\sum_{s'} V_{s'}^{a\to i}}{\prod_{a\in\partial i}\sum_{s''} V_{s''}^{a\to i}}}_{=1}$$
$$= \frac{g_i(s_i)\prod_{a\in\partial i} \frac{V_{s_i}^{a\to i}}{\sum_{s''} V_{s''}^{a\to i}}}{\sum_s g_i(s)\prod_{a\in\partial i} \frac{V_s^{a\to i}}{\sum_{s'} V_{s'}^{a\to i}}} = \frac{g_i(s_i)\prod_{a\in\partial i}\psi_{s_i}^{a\to i}}{\sum_s g_i(s)\prod_{a\in\partial i}\psi_s^{a\to i}} = \underbrace{\frac{1}{Z^i} g_i(s_i)\prod_{a\in\partial i}\psi_{s_i}^{a\to i}}_{=:\chi_{s_i}^i},$$
$$Z^i := \sum_s g_i(s)\prod_{a\in\partial i}\psi_s^{a\to i}.$$

可以看到，每个边缘分布 $\mu_i(s_i)$ 都是传入消息 $\psi_{s_i}^{a\to i}$（$a\in\partial i$）的一个非常简单的函数。

另一方面，将树的根取为节点 i，即可直接计算配分函数（与根节点 i 的选择无关）：

$$Z = \sum_{s_i} g_i(s_i)\prod_{a\in\partial i} V_{s_i}^{a\to i}. \qquad (\dagger)$$

我们希望得到一个仅含消息 χ 与 ψ 的 Z 的表达式，使其不显含树根。首先定义

$$Z^i := \sum_s g_i(s)\prod_{a\in\partial i}\psi_s^{a\to i} = \frac{\sum_s g_i(s)\prod_{a\in\partial i} V_s^{a\to i}}{\prod_{a\in\partial i}\sum_{s'} V_{s'}^{a\to i}},$$
$$Z^a := \sum_{\{s_i\}_{i\in\partial a}} f_a(\{s_i\}_{i\in\partial a})\prod_{i\in\partial a}\chi_{s_i}^{i\to a} = \frac{\sum_{\{s_i\}_{i\in\partial a}} f_a(\{s_i\}_{i\in\partial a})\prod_{i\in\partial a} R_{s_i}^{i\to a}}{\prod_{i\in\partial a}\sum_{s'} R_{s'}^{i\to a}},$$
$$Z^{ia} := \sum_s \chi_s^{i\to a}\psi_s^{a\to i} = \frac{\sum_s V_s^{a\to i} R_s^{i\to a}}{(\sum_{s'} V_{s'}^{a\to i})(\sum_{s''} R_{s''}^{i\to a})}.$$

现在证明

$$Z=\frac{\prod_{i=1}^{N}Z^{i}\prod_{a=1}^{M}Z^{a}}{\prod_{(ia)\in E}Z^{ia}}.$$

由定义出发，

$$\begin{aligned}\frac{\prod_i Z^i\prod_a Z^a}{\prod_{(ia)\in E}Z^{ia}}&=\frac{\prod_{i=1}^{N}\frac{\sum_s g_i(s)\prod_{a\in\partial i}V_s^{a\to i}}{\prod_{a\in\partial i}\sum_{s'}V_{s'}^{a\to i}}\prod_{a=1}^{M}\frac{\sum_{\{s_i\}_{i\in\partial a}}f_a(\{s_i\}_{i\in\partial a})\prod_{i\in\partial a}R_{s_i}^{i\to a}}{\prod_{i\in\partial a}\sum_{s'}R_{s'}^{i\to a}}}{\prod_{(ia)\in E}\frac{\sum_s V_s^{a\to i}R_s^{i\to a}}{(\sum_{s'}V_{s'}^{a\to i})(\sum_{s''}R_{s''}^{i\to a})}}\\&=\frac{\prod_{i=1}^{N}\frac{\sum_s g_i(s)\prod_{a\in\partial i}V_s^{a\to i}}{\prod_{(ia)\in E}\sum_{s'}V_{s'}^{a\to i}}\cdot\frac{\prod_{a=1}^{M}\sum_{\{s_i\}_{i\in\partial a}}f_a(\{s_i\}_{i\in\partial a})\prod_{i\in\partial a}R_{s_i}^{i\to a}}{\prod_{(ia)\in E}\sum_{s'}R_{s'}^{i\to a}}}{\frac{\prod_{(ia)\in E}\sum_s V_s^{a\to i}R_s^{i\to a}}{\left(\prod_{(ia)\in E}\sum_{s'}V_{s'}^{a\to i}\right)\left(\prod_{(ia)\in E}\sum_{s''}R_{s''}^{i\to a}\right)}}\\&=\frac{\prod_{i=1}^{N}\sum_s g_i(s)\prod_{a\in\partial i}V_s^{a\to i}\prod_{a=1}^{M}\sum_{\{s_i\}_{i\in\partial a}}f_a(\{s_i\}_{i\in\partial a})\prod_{i\in\partial a}R_{s_i}^{i\to a}}{\prod_{(ia)\in E}\sum_s V_s^{a\to i}R_s^{i\to a}}.\end{aligned}$$

这里，原式中变量节点各邻接边上的 $\sum_{s'}V_{s'}^{a\to i}$ 与因子节点各邻接边上的 $\sum_{s'}R_{s'}^{i\to a}$，分别与分母中的同类因子逐边消去。

将树的根取在节点 j。根据式 (*)，有

$$\begin{aligned}\frac{\prod_i Z^i\prod_a Z^a}{\prod_{(ia)\in E}Z^{ia}}=&\left[\sum_s g_j(s)\prod_{a\in\partial j}V_s^{a\to j}\right]\left[\prod_{\substack{i=1\\i\neq j}}^{N}\sum_s V_s^{b\to i}\underbrace{g_i(s)\prod_{a\in\partial i\setminus b}V_s^{a\to i}}_{=R_s^{i\to b}}\right]\\&\times\left[\prod_{a=1}^{M}\sum_{s_i}R_{s_i}^{i\to a}\underbrace{\sum_{\{s_k\}_{k\in\partial a\setminus i}}f_a(\{s_k\}_{k\in\partial a})\prod_{k\in\partial a\setminus i}R_{s_k}^{k\to a}}_{=V_{s_i}^{a\to i}}\right]\\&\times\left[\prod_{(ia)\in E}\sum_s V_s^{a\to i}R_s^{i\to a}\right]^{-1}.\end{aligned}$$

再根据式 (†)，得到

$$\frac{\prod_i Z^i\prod_a Z^a}{\prod_{(ia)\in E}Z^{ia}}=Z\,\frac{\prod_{\substack{i=1\\i\neq\text{根}j}}^{N}\underbrace{\sum_s R_s^{i\to b}V_s^{b\to i}}_{b\text{ 是}i\text{ 朝根方向的邻点}}\prod_{a=1}^{M}\underbrace{\sum_s V_s^{a\to i}R_s^{i\to a}}_{i\text{ 是}a\text{ 朝根方向的邻点}}}{\prod_{(ia)\in E}\sum_s V_s^{a\to i}R_s^{i\to a}}=Z.$$

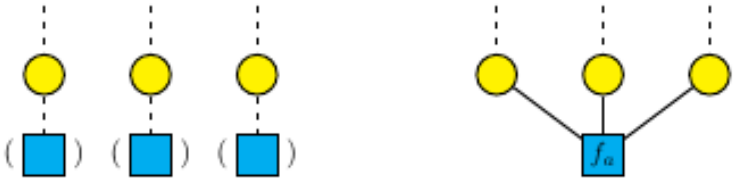
最后一步利用树的性质：对每个变量节点取朝向根的边，再对每个因子节点取朝向根的边，便恰好遍历所有边。

记住这些自由能项的含义很有启发性；由定义可知：

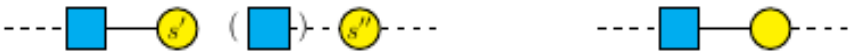
- Z^i：向因子图加入变量节点 i 时，配分函数 Z 的变化。



- Z^a：向因子图加入因子节点 a 时，配分函数 Z 的变化。



- Z^{ia}：将变量节点 i 与因子节点 a 相连时，Z 的变化。



因此，配分函数公式具有直观解释：先将所有变量节点和因子节点的贡献相加。由于每次添加节点都计入了与它相连的所有边，最终每条边被恰好计数两次（一次来自变量节点，一次来自因子节点）。为纠正这种重复计数，需要减去一次边的贡献。

5.2.2 信念传播方程总结

经过较长的推导，现在总结信念传播方程以及边缘分布、自由熵的公式。考虑表示下列概率分布的图模型：

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z}\prod_{i=1}^N g_i(s_i)\prod_{a=1}^M f_a(\{s_i\}_{i\in\partial a}).$$

信念传播方程为

$$\chi_{s_j}^{j\to a} = \frac{1}{Z^{j\to a}} g_j(s_j)\prod_{b\in\partial j\backslash a}\psi_{s_j}^{b\to j},$$

$$\psi_{s_i}^{a\to i} = \frac{1}{Z^{a\to i}}\sum_{\{s_j\}_{j\in\partial a\backslash i}} f_a(\{s_j\}_{j\in\partial a})\prod_{j\in\partial a\backslash i}\chi_{s_j}^{j\to a},$$

其中归一化因子 $Z^{j\to a}$ 和 $Z^{a\to i}$ 使得 $\sum_s \chi_s^{j\to a}=1$、$\sum_s \psi_s^{a\to i}=1$。自由熵密度 Φ 满足

$$N\Phi = \log Z = \sum_{i=1}^N \log Z^i + \sum_{a=1}^M \log Z^a - \sum_{(ia)} \log Z^{ia}, \tag{5.1}$$

该表达式在树上精确成立，在更一般的图上称为 Bethe 自由熵，其中

$$
\begin{aligned}
Z^i &:= \sum_s g_i(s) \prod_{a\in\partial i} \psi_s^{a\to i}, \\
Z^a &:= \sum_{\{s_i\}_{i\in\partial a}} f_a(\{s_i\}_{i\in\partial a}) \prod_{i\in\partial a} \chi_{s_i}^{i\to a}, \\
Z^{ia} &:= \sum_s \chi_s^{i\to a}\psi_s^{a\to i}.
\end{aligned}
$$

变量 i 的边缘分布为

$$
\mu_i(s_i) = \frac{1}{Z^i} g_i(s_i) \prod_{a\in\partial i} \psi_{s_i}^{a\to i}.
$$

信念传播与 Bethe 熵的一个标志性性质是：BP 方程可以由 Bethe 自由熵的驻点条件得到。请将其作为课后习题证明。当 BP 存在多个不动点时，这一性质对于寻找正确的不动点至关重要。

成功的方法或算法常常在不同领域被独立发现，信念传播也是如此。以各种形式引入 BP 的重要工作包括：

- Hans Bethe 与 Rudolf Peierls，1935 年：在磁学中，用度数相同的树近似规则晶格。
- Robert G. Gallager，1962 年，Gallager (1962)：在信息论中，用于稀疏纠错码的译码。
- Judea Pearl，1982 年，Pearl (1982)：用于贝叶斯推断。

5.2.3 如何使用信念传播？

以上推导了树形因子图上的 BP 方程和自由熵。为了将 BP 用作树上的算法，我们根据定义在叶节点初始化消息 $\chi_{s_j}^{j\to a} = g_j(s_j)$，再朝根传播。只需一次迭代。问题在于，基本上没有我们感兴趣的问题定义在树形图模型上，因此这一情形中的用途很有限。**译注：** 原文这里直接令叶消息等于 g_j；若使用前述归一化消息定义，一般还需除以 $\sum_s g_j(s)$。本句保留原文写法。

对于含有回路的图模型，始终可以把 BP 用作启发式迭代算法：

$$
\begin{aligned}
\chi_{s_j}^{j\to a}(t+1) &= \frac{1}{Z^{j\to a}(t)} g_j(s_j) \prod_{b\in\partial j\setminus a} \psi_{s_j}^{b\to j}(t), \\
\psi_{s_i}^{a\to i}(t) &= \frac{1}{Z^{a\to i}(t)} \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}(t).
\end{aligned}
$$

初始化有多种选择：

- $\chi_{s_j}^{j\to a}(t=0) = g_j(s_j)/\sum_s g_j(s)$，即按 “先验” 初始化。
- $\chi_{s_j}^{j\to a}(t=0) = g_j(s_j) + \varepsilon_{s_j}^{j\to a}$，再归一化；$\varepsilon_{s_j}^{j\to a}$ 是对 “先验” 的小扰动。
- $\chi_{s_j}^{j\to a}(t=0) = \varepsilon_{s_j}^{j\to a}$，再归一化，即随机初始化。
- $\chi_{s_j}^{j\to a}(t=0) = \delta_{s_j,s_j^*}$，即植入初始化。

后续讲义将讨论不同初始化的用途和性质。随后迭代信念传播方程，直到收敛或达到给定步数。更新顺序可以是并行的，也可以是随机顺序的；后文还将讨论不同更新方案的优缺点。

需要指出，如果图不是树，那么给定某个节点的取值后，各分支通常不再独立。一般而言，BP 方程中的乘积应当涉及联合概率分布。这时，算法的简单递推结构将被邻域（直至很大距离）上的联合概率分布取代，计算上会与原问题同样难以处理。本讲将说明，在许多情形下，传入消息 $\psi_{s_j}^{b\to i}$（$b\in\partial j\setminus a$）之间，以及 $\chi_{s_j}^{j\to a}$（$j\in\partial a\setminus i$）之间近似独立。我们重点关注由此得到的结果在 N 的主导阶上精确的情形。稀疏随机因子图是一类重要的图模型，BP 及其变体在其上可给出渐近精确的结果；这是因为，这类图在随系统大小呈对数增长的距离内看起来像树。**译注：**原文此处传入消息记作 $\psi_{s_j}^{b\to i}$，与邻域 $\partial j\setminus a$ 的目标节点记号不一致，照录并记录。

稀疏随机图具有局部树状结构

非正式地说，如果对几乎所有节点而言，距离 d 以内的邻域是一棵树，且当 $N\to\infty$ 时 $d\to\infty$，就称图具有局部树状结构。

稀疏随机因子图具有局部树状结构。这里“稀疏”是指，当图的大小 $N,M\to\infty$ 时，变量节点与因子节点的平均度均保持为常数。

我们用稀疏随机图说明这一论断；稀疏随机因子图的论证类似。在随机图中，每条边以概率 $c/(N-1)$ 存在，其中 $c=O(1)$、$N\to\infty$，节点的平均度为 c。

为了计算经过典型节点 i 的最短回路长度，考虑从 i 出发的非回溯扩散过程。该过程在 d 步后经由某条回路返回 i 的概率为

$$1-\Pr(\text{不返回}i)\approx 1-\left(1-\frac{1}{N}\right)^{c^d},$$

其中 c^d 是 d 步后所探索节点数的期望。在 $N\to\infty$、$c=O(1)$ 的极限下，对于小距离 d，这一概率指数小；对于大距离 d，它指数接近 1。该概率达到 $O(1)$ 的距离 d 标志着经过节点 i 的最短回路长度的量级：

$$c^d\log\left(1-\frac{1}{N}\right)=c^d\left(-\frac{1}{N}-\frac{1}{2N^2}+\cdots\right)\approx O(1).$$

当 $c^d\approx O(N)$，即 $d\approx\log N/\log c$ 时，便会发生这种情况。由此得出，对于平均度 $c=O(1)$ 的随机图，经过随机节点 i 的最短回路长度以高概率为 $O(\log N)$。因此，在 $O(\log N)$ 的距离内，典型节点的邻域是一棵树。**译注：**以上是原文的启发式估计。$\log c$ 的表达式及关于最短回路的结论需要区分 $c>1$、有限分量与树分量等条件；“$O(\log N)$ 距离内”也不能理解为任意常数倍的对数半径均无回路。原文未在这里给出精确定理。

因此，我们将尝试在局部树状图上使用信念传播和 Bethe 自由熵。BP 的关键假设是树的各分支相互独立。如果分支通过长度 $O(\log N)\to\infty$ 的回路连接，并且根与叶节点间的关联衰减得足够快（我们将更精确地表述这一条件），那么分支的独立性便渐近恢复，BP 与 Bethe 自由熵就会给出渐近精确的结果。我们既将研究关联衰减足够快的情形，也将研究衰减不够快的情形，并说明如何继续使用基于 BP 的方法，得到经过调整的渐近精确结果；这将引出副本对称破缺的概念。

5.3 习题

习题 5.1：用图模型和信念传播表示问题

将以下问题写成：(i) 概率分布；(ii) 图模型，并画出对应因子图的一个小例子。最后，(iii) 写出这些问题的信念传播方程（无需编程或求解），以及从 BP 不动点计算的 Bethe 自由能表达式。

1. p **自旋模型**。物理学中常研究所谓的 Ising 三自旋模型，其 Hamiltonian 写为

$$\mathcal{H}(\{S_i\}_{i=1}^N) = -\sum_{(ijk)\in E} J_{ijk} S_i S_j S_k - \sum_{i=1}^N h_i S_i. \tag{5.2}$$

   其中 E 是由互异指标 $i \neq j \neq k$ 的无序三元组组成的给定集合，J_{ijk} 是三元组 $(ijk) \in E$ 的相互作用强度，h_i 是自旋 i 上的磁场。自旋是 Ising 自旋，在物理学中意为 $S_i \in \{+1, -1\}$。

2. **独立集问题**。这是组合数学和图论中定义、研究的问题。给定无权无向图 $G(V, E)$，独立集 $S \subseteq V$ 是满足如下条件的节点子集：若 $i \in S$，则对所有 $j \in \partial i$ 都有 $j \notin S$。换言之，对每条 $(ij) \in E$，i 和 j 至多只有一个属于独立集。

   (a) 写出给定图上所有独立集上的均匀概率分布。

   (b) 写出对较大独立集赋予较大权重的概率分布；独立集的大小就是 $|S|$。

3. **匹配问题**。匹配是图论中的另一个经典问题，与统计物理中的二聚体问题有关。给定无权无向图 $G(V, E)$，匹配 $M \subseteq E$ 是这样的边子集：若 $(ij) \in M$，则包含节点 i 或 j 的其他边都不能属于 M。换言之，匹配中的任意两条边均不共享节点。

   (a) 写出给定图上所有匹配上的均匀概率分布。

   (b) 写出对较大匹配赋予较大权重的概率分布；匹配的大小就是 $|M|$。

习题 5.2：Bethe 自由熵

信念传播与 Bethe 自由熵之间有一个关键联系。证明讲义中推导的 BP 方程

$$\chi_{s_j}^{j\to a} = \frac{1}{Z^{j\to a}} g_j(s_j) \prod_{b\in\partial j\setminus a} \psi_{s_j}^{b\to j},$$

$$\psi_{s_i}^{a\to i} = \frac{1}{Z^{a\to i}} \sum_{\{s_j\}_{j\in\partial a\setminus i}} f_a(\{s_j\}_{j\in\partial a}) \prod_{j\in\partial a\setminus i} \chi_{s_j}^{j\to a}$$

是在对所有 $(ia) \in E$ 都有 $\sum_s \psi_s^{a\to i} = 1$ 和 $\sum_s \chi_s^{i\to a} = 1$ 的约束下，Bethe 自由熵式 (5.1) 的驻点条件。

附录 5.A：逐节点理解两体模型的 BP

在第 5.2 节，我们为一般树状图模型推导了信念传播（BP）方程。初看之下，这些方程或许令人望而生畏。本附录在一个具体情形中，从头开始逐节点构造 BP 方程，以帮助建立直观理解。

设 $G=(V,E)$ 是具有 $N=|V|$ 个节点的图。具体考虑 G 上的两体相互作用自旋模型：

$$P(S=s)=\frac{1}{Z}\prod_{i=1}^{N}g_i(s_i)\prod_{(ij)\in E}f_{(ij)}(s_i,s_j).$$

这一形式涵盖许多有趣的情形，例如前面研究的 RFIM，其中

$$g_i(s_i)=e^{\beta h_i s_i},\qquad f_{(ij)}(s_i,s_j)=e^{\beta s_i s_j}\qquad(\text{RFIM}),$$

以及本章研究的 $q=2$ 图着色问题，其中

$$g_i(s_i)=1,\qquad f_{(ij)}(s_i,s_j)=e^{\beta\delta_{s_i s_j}}\qquad(\text{图着色}).$$

译注：图着色因子的指数在原文此处为正号，与本章前文软着色权重的负号不同；按可见原式保留。

在下文中，读者可始终以这两个问题中的任一个为例。为简化记号，将概率分布写成 $\mu(s):=P(S=s)$，其中 μ 视为函数 $\mu:\{-1,1\}^N\to[0,1]$。我们还用 $\propto$ 表示“相差一个乘法因子”；这里，该因子始终指使概率分布或消息归一化的常数。回顾 BP 方程是变量到因子的消息或信念 $\chi_{s_i}^{i\to a}$ 与因子到变量的消息或信念 $\psi_{s_i}^{a\to i}$ 的自洽方程。两体模型中，每条边对应一个因子，BP 方程为

$$\chi_{s_j}^{j\to(ij)}=\frac{1}{Z^{j\to(ij)}}g_j(s_j)\prod_{(kj)\in\partial j\setminus(ij)}\psi_{s_j}^{(kj)\to j},$$
$$\psi_{s_i}^{(ij)\to i}=\frac{1}{Z^{(ij)\to i}}\sum_{\{s_j\}_{j\in\partial(ij)\setminus i}}f_{(ij)}(s_i,s_j)\prod_{j\in\partial(ij)\setminus i}\chi_{s_j}^{j\to(ij)}.$$

由于两体模型中的边与因子节点一一对应，可以直接在图 G 上重写 BP 方程。对每个节点 $i\in V$，定义发出消息 $\chi_{s_i}^{i\to j}:=\chi_{s_i}^{i\to(ij)}$ 和传入消息 $\psi_{s_i}^{j\to i}=\psi_{s_i}^{(ij)\to i}$。以这些“新”消息表示的 BP 方程为

$$\chi_{s_i}^{i\to j}=\frac{1}{Z^{i\to j}}g_i(s_i)\prod_{k\in\partial i\setminus j}\psi_{s_i}^{k\to i},\qquad\psi_{s_i}^{k\to i}=\frac{1}{Z^{k\to i}}\sum_{s_k\in\{-1,1\}}f_{(ik)}(s_i,s_k)\chi_{s_k}^{k\to i}.$$

回顾，变量 s_i 的边缘分布用消息表示为

$$\mu_i(s_i):=P(S_i=s_i)\propto g_i(s_i)\prod_{j\in\partial i}\psi_{s_i}^{j\to i}.\tag{5.3}$$

这就是说，$S_i=s_i$ 的概率由“局域信念”（或先验）g_i 乘以所有邻居向 i 传入的信念 $\psi_{s_i}^{j\to i}$ 给出。换言之，BP 把每个节点的边缘分布分解为独立信念的乘积。

注意，此时还可以消去其中一类消息，得到仅含另一类消息的自洽方程。例如，消去传入消息 $\psi_{s_k}^{k\to i}$，得到

$$\chi_{s_i}^{i\to j}=\frac{g_i(s_i)}{Z^{i\to j}}\prod_{k\in\partial i\setminus j}\sum_{s_k\in\{-1,+1\}}f_{(ik)}(s_i,s_k)\chi_{s_k}^{k\to i}.$$

译注：前一句传入消息的下标 s_k 为原文写法，前面定义的相应消息下标为 s_i。

5.A.1 一个节点

当图只有一个节点，即 $N=1$ 时，只有一个自旋 $S_1\in\{-1,1\}$，故 $E=\varnothing$。对应因子图含有一个变量节点，以及表示 “局域场”g_i 的一个因子节点。此时，自旋 S_1 的边缘分布直接由 “局域信念” 给出：

$$\mu(\pm1):=P(S_1=\pm1)=\frac{1}{Z}g_i(\pm1)=\frac{g_1(\pm1)}{g_1(+1)+g_1(-1)}.$$

注意，若不存在先验，即 $g_1(s_1)=1$，则边缘分布就是均匀分布 $\mu_1(s_1)=1/2$。

5.A.2 两个节点

当有两个节点 $N=2$ 时，自旋变量为 $S_1,S_2\in\{-1,+1\}$，图有两种可能：自旋互不耦合，$E=\varnothing$；或者它们通过一条边相互作用，$E=\{(12)\}$。

无边。 第一种情形的联合分布为

$$\begin{aligned}\mu(s_1,s_2)&=\frac{1}{Z}g_1(s_1)g_2(s_2)\\&=\frac{g_1(s_1)g_2(s_2)}{g_1(+1)g_2(+1)+g_1(-1)g_2(+1)+g_1(+1)g_2(-1)+g_1(-1)g_2(-1)}.\end{aligned}$$

S_1 的边缘分布为

$$\begin{aligned}\mu_1(s_1)&=\sum_{s_2\in\{-1,+1\}}\mu(s_1,s_2)=\mu(s_1,-1)+\mu(s_1,+1)\\&=\frac{g_2(-1)+g_2(+1)}{g_1(+1)g_2(+1)+g_1(-1)g_2(+1)+g_1(+1)g_2(-1)+g_1(-1)g_2(-1)}g_1(s_1).\end{aligned}$$

交换 $1\leftrightarrow2$ 即得 S_2 的边缘分布。注意，此时联合分布分解为边缘分布的乘积：

$$\mu(s_1,s_2)=\mu_1(s_1)\mu_2(s_2).$$

这是两个自旋之间不存在相互作用耦合项的直接结果。注意，此时没有因子，因此不能写出 BP 方程。**译注：** 这里 “没有因子” 对应没有边上的两体因子；上一小节的局域因子 g_i 仍然存在。

一条边。 $E=\{(12)\}$ 的情形更有意思。联合分布为

$$\mu(s_1,s_2)=\frac{1}{Z}g_1(s_1)g_2(s_2)f_{(12)}(s_1,s_2).$$

注意，归一化因子 Z 的精确表达式很快便变得繁琐，故从现在起不再将它显式写出。边缘分布为

$$\begin{aligned}\mu_1(s_1)&=\frac{1}{Z}[g_2(+1)f_{(12)}(s_1,+1)+g_2(-1)f_{(12)}(s_1,-1)]g_1(s_1),\\\mu_2(s_2)&=\frac{1}{Z}[g_1(+1)f_{(12)}(+1,s_2)+g_1(-1)f_{(12)}(-1,s_2)]g_2(s_2).\end{aligned}$$

关键是，容易验证联合分布不再分解：

$$\mu(s_1,s_2)\neq\mu_1(s_1)\mu_2(s_2).$$

现在看看 BP 方程告诉了我们什么。例如，发出消息为

$$\chi^{1\to 2}_{s_1} \propto g_1(s_1), \qquad\qquad \chi^{2\to 1}_{s_2} \propto g_2(s_2),$$

而传入消息为

$$\begin{aligned}
\psi^{2\to 1}_{s_1} &\propto \sum_{s_2\in\{-1,+1\}} f_{(12)}(s_1,s_2)\chi^{2\to 1}_{s_2} \\
&\propto \sum_{s_2\in\{-1,+1\}} f_{(12)}(s_1,s_2) f_{(12)}(s_1,s_2) g_2(s_2) \\
&\propto f_{(12)}(s_1,-1)g_2(-1) + f_{(12)}(s_1,+1)g_2(+1), \\
\psi^{1\to 2}_{s_2} &\propto \sum_{s_1\in\{-1,+1\}} f_{(12)}(s_1,s_2)\chi^{1\to 2}_{s_1} \\
&\propto \sum_{s_1\in\{-1,+1\}} f_{(12)}(s_1,s_2) f_{(12)}(s_1,s_2) g_1(s_1) \\
&\propto f_{(12)}(-1,s_2)g_1(-1) + f_{(12)}(+1,s_1)g_1(+1).
\end{aligned}$$

由此可以清楚地看到，边缘分布按照式 (5.3) 分解为局域信念与传入信念的乘积。**译注：** 原文两组消息的第二行均重复乘入 $f_{(12)}$，与前后两行一般不等价；末行的 $f_{(12)}(+1,s_1)$ 也与左侧 s_2 不一致。均按原式保留。前述联合分布 “不再分解” 的断言针对通常的相互作用情形，并非对任意可分解因子均成立。

5.A.3 三个节点

最后考虑更复杂的三个节点 $N=3$ 情形。没有边 $E=\varnothing$ 或只有一条边 $|E|=1$ 时，问题归结为前面讨论过的情形。因此，值得关注的是两条边或三条边的情况。

两条边。 当有两条边时，两个节点的度为 1，一个节点的度为 2。不失一般性，可令节点 2 的度为 2，则联合分布为

$$\mu(s_1,s_2,s_2) = \frac{1}{Z} f_{(12)}(s_1,s_2) f_{(23)}(s_2,s_3) g_1(s_1) g_2(s_2) g_3(s_3).$$

于是 $S_1 = s_1$ 的边缘概率为

$$\begin{aligned}
\mu_1(s_1) &= \sum_{s_2\in\{-1,1\}} \sum_{s_3\in\{-1,1\}} \mu(s_1,s_2,s_2) \\
&\propto \Big[\big(f_{(23)}(-1,-1)g_3(-1) + f_{(23)}(-1,+1)g_2(-1)g_3(+1) \big) f_{(12)}(s_1,-1)g_2(-1) \\
&\qquad + \big(f_{(23)}(+1,-1)g_3(-1) + f_{(23)}(+1,+1)g_3(+1) \big) f_{(12)}(s_1,+1)g_2(+1) \Big] g_1(s_1).
\end{aligned}$$

注意，四项中每两项共享一个公因子。发出的 BP 消息现在为

$$\chi^{1\to 2}_{s_1} \propto g_1(s_1), \qquad \chi^{2\to 1}_{s_2} \propto g_2(s_2) \sum_{s_3\in\{-1,+1\}} f_{(23)}(s_2,s_3)\chi^{3\to 2}_{s_3}, \qquad \chi^{3\to 2}_{s_3} \propto g_3(s_3).$$

将第一式和第三式代入第二式，得

$$\chi^{2\to 1}_{s_2} \propto g_2(s_2) \sum_{s_3\in\{-1,+1\}} f_{(23)}(s_2,s_3) g_3(s_3)$$

$$\propto [f_{(23)}(s_2,-1)g_3(-1)+f_{(23)}(s_2,+1)g_3(+1)]g_2(s_2).$$

容易验证，借助式 (5.3)，这使我们能够重构 $S_1=s_1$ 的边缘分布：

$$\begin{aligned}\mu_1(s_1) &\propto g_1(s_1)\sum_{s_2\in\{-1,+1\}} f_{(12)}(s_1,s_2)\chi_{s_2}^{2\to1}\\ &\propto g_1(s_1)\sum_{s_2\in\{-1,+1\}} f_{(12)}(s_1,s_2)[f_{(23)}(s_2,-1)g_3(-1)+f_{(23)}(s_2,+1)g_3(+1)]g_2(s_2).\end{aligned}$$

译注：本页联合分布及其求和的第三个自变量均印为 s_2，与右侧的 s_3 不一致；最初边缘分布展开中还多出一项 $g_2(-1)$。原文 “将第一式和第三式代入第二式” 中，实际第二式只使用第三式。以上均保留原文，并与后续 BP 重构式区分。

三**条边**。 当有三条边时，所有节点两两相连，度均为 2。联合分布为

$$\mu(s_1,s_2,s_2)=\frac{1}{Z}f_{(12)}(s_1,s_2)f_{(13)}(s_1,s_3)f_{(23)}(s_2,s_3)g_1(s_1)g_2(s_2)g_3(s_3).$$

此时 $S_1=s_1$ 的边缘概率为

$$\begin{aligned}\mu_1(s_1) &= \sum_{s_2\in\{-1,1\}}\sum_{s_3\in\{-1,1\}}\mu(s_1,s_2,s_2)\\ &\propto \Big[f_{(12)}(s_1,-1)f_{(13)}(s_1,-1)g_2(-1)g_3(-1)\\ &\quad + f_{(12)}(s_1,+1)f_{(13)}(s_1,-1)g_2(+1)g_3(-1)\\ &\quad + f_{(12)}(s_1,-1)f_{(13)}(s_1,+1)g_2(-1)g_3(+1)\\ &\quad + f_{(12)}(s_1,+1)f_{(13)}(s_1,+1)g_2(+1)g_3(+1)\Big]g_1(s_1).\end{aligned}$$

注意，与两个节点的情形不同，以上四项除了 $g_1(s_1)$ 之外，没有共同因子。发出的 BP 消息为

$$\begin{aligned}&\chi_{s_1}^{1\to2}\propto g_1(s_1)\sum_{s_3\in\{-1,1\}} f_{(13)}(s_1,s_3)\chi_{s_3}^{3\to1}, \qquad \chi_{s_1}^{1\to3}\propto g_1(s_1)\sum_{s_2\in\{-1,1\}} f_{(12)}(s_1,s_2)\chi_{s_2}^{2\to1},\\ &\chi_{s_2}^{2\to1}\propto g_2(s_2)\sum_{s_3\in\{-1,1\}} f_{(23)}(s_2,s_3)\chi_{s_3}^{3\to2}, \qquad \chi_{s_2}^{2\to3}\propto g_2(s_2)\sum_{s_1\in\{-1,1\}} f_{(21)}(s_2,s_1)\chi_{s_1}^{1\to2},\\ &\chi_{s_3}^{3\to1}\propto g_3(s_3)\sum_{s_2\in\{-1,1\}} f_{(32)}(s_3,s_2)\chi_{s_2}^{2\to3}, \qquad \chi_{s_3}^{3\to2}\propto g_3(s_3)\sum_{s_1\in\{-1,1\}} f_{(31)}(s_3,s_1)\chi_{s_1}^{1\to3}.\end{aligned}$$

注意，此时消息不易求解。例如，$S_1=s_1$ 的边缘分布由下式给出：

$$\mu_1(s_1)\propto g_1(s_1)\sum_{s_2\in\{-1,+1\}} f_{(12)}(s_1,s_2)\chi_{s_2}^{2\to1},$$

因此它依赖于 $\chi_{s_2}^{2\to1}$。但 $\chi_{s_2}^{2\to1}$ 依赖于 $\chi_{s_3}^{3\to2}$，后者又依赖于 $\chi_{s_1}^{1\to3}$，而后者又依赖于 $\chi_{s_2}^{2\to1}$。换言之，无法将边缘分布分解为独立消息的乘积，因为移除一条边（例如 (12)）并不能使变量 S_1 与 S_2 独立；二者仍通过与 S_3 的共同连接而相关。这是所考虑图中存在回路的直接结果。**译注：**三条边情形的联合分布仍将第三个自变量印为 s_2；其最初四项边缘展开未包含 $f_{(23)}(s_2,s_3)$；最后的单求和式也缺少来自节点 3 的传入因子，因而一般不是精确边缘分布。原式保留，不能将这里的启发式表述当作含回路图上的精确等式。

6 图着色的信念传播

当每种颜色都与相邻颜色十分不同时，画面就会富有魅力。

Leon Battista Alberti，1404–1472

如前所述，给定图 $G(V,E)$ 和颜色 $s_i \in \{1,2,\dots,q\}$，图着色中要研究的概率分布为

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z_G(\beta)} \prod_{(ij)\in E} e^{-\beta\delta_{s_i,s_j}}. \tag{6.1}$$

在物理学中，这类变量称为 Potts 自旋，相应模型称为 Potts 模型。下文将同时考虑 $\beta > 0$ 的排斥（反铁磁）情形与 $\beta < 0$ 的吸引（铁磁）情形。按照我们的记号，对所有 i，节点因子为 $g_i(s_i) = 1$；对所有 $(ij) \in E$，相互作用因子为 $f_{(ij)}(s_i, s_j) = e^{-\beta\delta_{s_i,s_j}}$。

6.1 导出所关心的量

现在说明如何计算所关心的量，例如给定能量的构型数。定义能量 $e = \sum_{(ij)\in E} \delta_{s_i,s_j}/N$，即每个节点对应的单色边数。记给定能量下的着色数为 $\mathcal{N}(e)$，并通过

$$\mathcal{N}(e) = e^{Ns(e)} \tag{6.2}$$

定义熵 $s(e)$。以 Φ 表示自由熵密度，则配分函数可改写为

$$\begin{aligned} e^{N\Phi(\beta)} = Z_G &= \sum_{\{s_i\}_{i=1}^N} e^{-\beta\sum_{(ij)\in E}\delta_{s_i,s_j}} \\ &= \sum_e \sum_{\text{能量为}e\text{ 的所有着色}} e^{-N\beta e} = \int de\, e^{Ns(e)-N\beta e}. \end{aligned}$$

第三步将求和分为给定能量 e 下所有构型的求和，以及对所有能量的求和；最后一步用对 e 的积分替代离散能量值上的和，并使用式 (6.2) 的定义。这是合理的，因为我们考虑 $N \to \infty$ 极限，且只关心 Φ, e, s 关于 N 的主导阶。鞍点法给出

$$\left.\frac{\partial s(e)}{\partial e}\right|_{e=e^*} = \beta, \qquad \Phi(\beta) = s(e^*) - \beta e^*. \tag{6.3}$$

从逆温度为 β 的 Boltzmann 分布采样得到的随机构型，其能量以高概率集中于 e^*，故 $\langle e\rangle_{\text{Boltz}} = e^*$。再回顾 Boltzmann 分布的便利性质：

$$\frac{d\Phi(\beta)}{d\beta} = -\langle e\rangle_{\text{Boltz}}. \tag{6.4}$$

因此，算出自由熵密度关于 β 的函数 Φ 后，就可以计算其导数，进而得到给定能量构型数对应的熵 $s(e)$。精确完成这些计算通常在计算上难以处理。我们将用 BP 和 Bethe 自由熵得到近似结果，在某些情形下这些结果渐近精确。

如何用信念传播计算上述量？BP 不动点给出一组消息 $\chi^{i\to j}$，以及作为这些消息的函数的 Bethe 自由熵 Φ_{Bethe}。一般而言，消息近似给出变量的真实边缘分布，Φ_{Bethe} 近似给出真实自由熵 Φ。记住 BP 不动点是 Bethe 自由熵的驻点，有

$$\frac{d\Phi_{\text{Bethe}}(\beta)}{d\beta} = \underbrace{\frac{\partial\Phi_{\text{Bethe}}}{\partial\chi}}_{\text{在 BP 不动点为0}} \cdot\frac{\partial\chi}{\partial\beta} + \frac{\partial\Phi_{\text{Bethe}}(\beta)}{\partial\beta}. \tag{6.5}$$

于是，给定 BP 不动点便可近似计算自由熵与平均能量。算出 Φ_{Bethe} 和 e^* 后，即可得到熵 $s(e)$；它被定义为能量 e 下着色数的对数：

$$s(e^*) = \Phi(\beta) + \beta e^*. \tag{6.6}$$

但要记住，所得 $s(e)$ 是否正确，取决于给定 BP 不动点下 Bethe 自由熵是否正确。**译注：**离散能量求和到积分及单一可微鞍点的关系是原文在大 N 主导阶上的处理，不能把前述积分等号或集中结论无条件理解为有限 N 精确恒等式；$s(e)$ 按定义是除以 N 后的对数。

6.2 将一般 BP 方程具体用于着色

现在应用上一章推导的 BP 方程，尽管一般的图 $G(V,E)$ 并不是树。下文将说明，在什么条件下，这能对随机图着色给出渐近精确的结果。注意，对一般图，此方法始终可视为所关心量的启发式近似；多数情况下，这种近似难以控制。本节将变换 BP 方程，考察能从中导出什么，并在必要时将讨论限制于随机稀疏图。

应用上一章的方法，得到

$$\chi^{j\to(ij)}_{s_j} = \frac{1}{Z^{j\to(ij)}} \prod_{(kj)\in\partial j\setminus(ij)} \psi^{(kj)\to j}_{s_j},$$
$$\psi^{(ij)\to i}_{s_i} = \frac{1}{Z^{(ij)\to i}} \sum_{s_j} e^{-\beta\delta_{s_i,s_j}} \chi^{j\to(ij)}_{s_j} = \frac{1}{Z^{(ij)\to i}} \big[1-(1-e^{-\beta})\chi^{j\to(ij)}_{s_i}\big].$$

每个因子节点只有两个邻居，因此第二个 BP 方程形式简单，乘积仅含一项。故可以消去消息 ψ，仍保持简单的形式：

$$\chi^{j\to(ij)}_{s_j} = \frac{1}{Z^{j\to(ij)} \prod_{(kj)\in\partial j\setminus(ij)} Z^{(kj)\to j}} \prod_{(kj)\in\partial j\setminus(ij)} \big[1-(1-e^{-\beta})\chi^{k\to(kj)}_{s_j}\big],$$
$$\Longrightarrow \quad \chi^{j\to i}_{s_j} = \frac{1}{Z^{j\to i}} \prod_{k\in\partial j\setminus i} \big[1-(1-e^{-\beta})\chi^{k\to j}_{s_j}\big].$$

最后一式中，定义了总归一化因子 $Z^{j\to i}$，并回到原图的记号：∂i 表示节点 i 的邻居节点集；在因子图记号中，它表示 i 的邻居因子集。初看之下，这种记号变化可能令人困惑，因为我们用同一个 χ 表示原图和因子图上的消息。但这并无歧义：两个变量节点之间的消息 $i\to j$ 只能指原图，因为在因子图中，两个变量节点不能直接连接。

所得 BP 方程具有直观含义。回顾，$\chi^{j\to i}_{s_j}$ 表示暂时移除 j 与 i 的连接后，节点 j 取颜色 s_j 的概率。据此，方程各部分的含义为

- $1-(1-e^{-\beta})\chi^{k\to i}_{s_j} = \sum_{s_k\neq s_j}\chi^{k\to i}_{s_k} + e^{-\beta}\chi^{k\to i}_{s_j}$：邻居 k 允许节点 j 取颜色 s_j 的概率。
- $\prod_{k\in\partial j\setminus i}[\cdots]$：所有邻居都允许 j 取颜色 s_j 的概率。由于边 (ij) 已移除，不包括 i。这里使用乘积，隐含了 BP 的假设：给定 s_j 后，各邻居相互独立。

译注：第一条的消息上标 $k\to i$ 为原文写法，前述递推相应为 $k\to j$；当 $\beta<0$ 时，该带权表达式一般不能直接称作 $[0,1]$ 内的概率。这里保留原文说明。

计算机科学中，信念传播通常被当作算法讨论。对于图着色，消息给出边缘概率，而不直接给出合法着色。在某些区域，可以通过变量抽取（decimation）从 BP 推得合法着色：逐个将变量固定为由收敛消息或给定迭代次数后消息的数值所确定的取值。后续章节将讨论该算法的效果。本章主要把 BP 用作分析工具。

6.3 着色的 Bethe 自由能

在课后习题中，将通过与上述类似的简化，证明图着色的一般 Bethe 自由熵可改写为

$$N\Phi_{\text{Bethe}}(\beta)=\sum_{i=1}^{N}\log Z^{(i)}-\sum_{(ij)\in E}\log Z^{(ij)}, \tag{6.7}$$

其中

$$\begin{aligned}Z^{(i)}&=\sum_{s}\prod_{k\in\partial i}\left[1-(1-e^{-\beta})\chi_s^{k\to i}\right],\\ Z^{(ij)}&=\sum_{s_i,s_j}e^{-\beta\delta_{s_i,s_j}}\chi_{s_i}^{i\to j}\chi_{s_j}^{j\to i}=1-(1-e^{-\beta})\sum_{s}\chi_s^{i\to j}\chi_s^{j\to i}.\end{aligned}$$

记住，Bethe 自由熵在 BP 方程的不动点处计算。有时也将 Bethe 自由熵视为所有消息 $\chi^{i\to j}$ 的函数，或视为消息某种参数化形式的函数。

使用 BP 近似计算自由熵时，我们始终加上 “Bethe” 下标。在树上，已证明 $\Phi=\Phi_{\text{Bethe}}$；对一般图（即便局部树状），后续讲义将更详细地讨论两者的关系，更确切地说，讨论其全局极大值点的关系。

注意，迄今所写的所有量，都通过节点集 V 和边集 E 显式依赖于图 $G(V,E)$；尚未对图（即无序）取任何平均！这与副本法大不相同，后者计算的第一步实际上就是对无序取平均。

6.4 图着色的顺磁不动点

注意，图着色中，对所有 (ij) 和 s_j，$\chi_{s_j}^{j\to i}=q^{-1}$ 在任意图 $G(V,E)$ 上都是 BP 方程的不动点，称为顺磁不动点。一般还可能存在、且常常存在其他不动点，后续小节将讨论。为验证 q^{-1} 的确是不动点，记节点 i 的度（邻居数）为 d_i，BP 递推给出

$$\frac{[1-(1-e^{-\beta})/q]^{d_i-1}}{q[1-(1-e^{-\beta})/q]^{d_i-1}}=\frac{1}{q}, \tag{6.8}$$

它确实恒成立。该顺磁不动点的 Bethe 自由熵为

$$\begin{aligned}N\Phi_{\text{Bethe}}(\beta)&=\sum_{i=1}^{N}\log\left\{q\left[1-(1-e^{-\beta})\frac{1}{q}\right]^{d_i}\right\}-\sum_{(ij)\in E}\log\left\{q\frac{1}{q^2}e^{-\beta}+(q^2-q)\frac{1}{q^2}\right\},\\ \Phi_{\text{Bethe}}(\beta)&=c\log\left[1-(1-e^{-\beta})\frac{1}{q}\right]+\log q-\frac{c}{2}\log\left[1-(1-e^{-\beta})\frac{1}{q}\right]\\ &=\log q+\frac{c}{2}\log\left[1-(1-e^{-\beta})\frac{1}{q}\right],\end{aligned}$$

其中 $c=\sum_i d_i/N=2M/N$ 是图的平均度。逆温度 β 下的平均能量和熵为

$$e^*=-\frac{\partial\Phi_{\text{Bethe}}(\beta)}{\partial\beta}=\frac{c}{2}\frac{e^{-\beta}/q}{1-(1-e^{-\beta})/q}=\frac{c}{2}\underbrace{\frac{e^{-\beta}}{(q-1)+e^{-\beta}}}_{\text{一条边为单色的概率}},$$

$$s(e^*)=\Phi_{\text{Bethe}}(\beta)+\beta e^*=\log q+\frac{c}{2}\log\left[1-(1-e^{-\beta})\frac{1}{q}\right]+\frac{\beta c}{2}\frac{e^{-\beta}}{(q-1)+e^{-\beta}}.$$

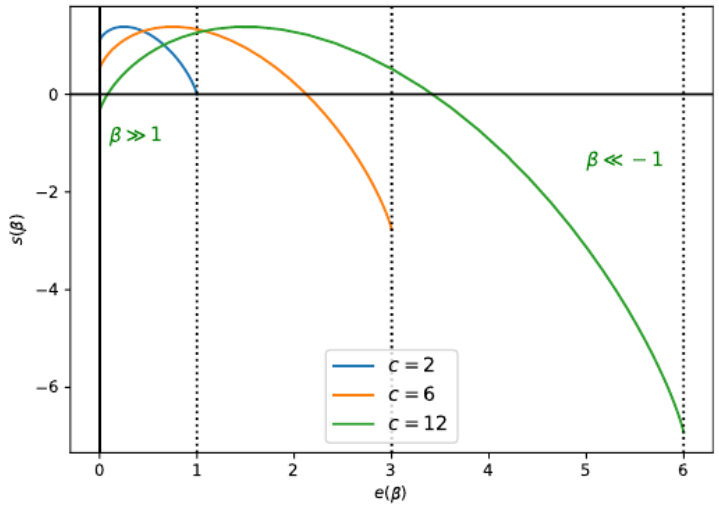


图 6.4.1: 图着色中熵随能量成本的变化，$q = 4$，对应信念传播的顺磁不动点。图的平均度为 c。

这些表达式给出了 $s(e)$ 的参数形式。有时甚至可以消去 β，得到 $s(e)$ 的闭合表达式；但通常只需画出参数曲线 $e(\beta), s(\beta)$。图中取 $q = 4$ 种颜色及若干平均度 c。对给定参数 c, q，$s(e)$ 曲线对应的能量范围为 0 至 $c/2$，因为至多所有边都违反约束。曲线在 $e = c/(2q)$ 处达到最大值 $\log q$：随机着色中，每条边以概率 $1/q$ 违反约束，因此这是其典型成本。曲线 $s(e)$ 的斜率对应逆温度 β，因为 $\partial s(e)/\partial e = \beta$。

记住，熵 s 是整数（给定能量下着色数）的对数，显然不应为负。图中大能量处，以及 $c = 12$ 时接近零能量处出现负值，说明要么相应能量的着色以高概率不存在，要么我们的计算有问题。还要注意，迄今除了平均度之外，未对图作任何限定。显然，平均度 $c = 6$ 的图可能含有一个或多个（甚至数量与 N 成正比的）5 团，因而不存在合法着色。因此，所得结果（对 $c = 6, e = 0$ 预示指数多个合法四色着色）不可能适用于这类图。从现在起，我们限制于随机稀疏图，考察所得结果至少在该情形下是否合理。

从顺磁不动点的结果可见，对所有 i 取 $\chi^i = 1/q$，便意味着某些严格小于 $c/2$ 的能量以上不可达到，因为熵为负。但若所有节点都取同一颜色，就自动达到 $e = c/2$。为协调这一表面矛盾，需要认识到，对所有 i 取 $\chi^i = 1/q$ 的顺磁不动点假设每种颜色出现的次数相同，而所有节点取同一颜色时显然并非如此。BP 往往存在多个不动点，需要选出正确的一个。一般应寻找自由熵较大的不动点；鞍点法告诉我们，正是它主导概率测度。图着色的大能量区域，即 $\beta < 0$，促使我们研究能打破各颜色均等出现的新不动点，称为铁磁不动点。**译注：** 原文关于“每种颜色出现次数相同”的说法是顺磁解的物理解释；单节点均匀边缘本身并不排除由对称性混合产生的强关联或同色构型。这里只保留原文论述，不把该解释当作严格推出的全局约束。

6.5 铁磁不动点

现在研究：对所有 $(ij) \in E$，BP 方程是否存在以下形式的不动点：

$$\chi_1^{i\to j} = a, \qquad \chi_s^{i\to j} = b = \frac{1-a}{q-1}, \qquad \forall s \neq 1. \tag{6.9}$$

此时图着色的 BP 方程为

$$\chi_{s_j}^{j\to i}=\frac{1}{Z^{j\to i}}\prod_{k\in\partial j\setminus i}[1-(1-e^{-\beta})\chi_{s_j}^{k\to j}],$$
$$a=\frac{1}{Z^{j\to i}}[1-(1-e^{-\beta})a]^{d_j-1}=:\frac{1}{Z^{j\to i}}A^{d_j-1},$$
$$b=\frac{1}{Z^{j\to i}}[1-(1-e^{-\beta})b]^{d_j-1}=:\frac{1}{Z^{j\to i}}B^{d_j-1},$$

归一化给出

$$Z^{j\to i}=(q-1)B^{d_j-1}+A^{d_j-1},$$
$$a=\frac{A^{d_j-1}}{(q-1)B^{d_j-1}+A^{d_j-1}},\qquad b=\frac{B^{d_j-1}}{(q-1)B^{d_j-1}+A^{d_j-1}}.\tag{6.10}$$

要使这一假设对每条 $(ij)\in E$ 都给出不动点，需要所有 j 均满足 $d_j\equiv d$。随机 d 正则图的每个变量节点度均为 d，恰好满足此条件。当然，也可以考虑 a 依赖于 (ij) 的铁磁不动点并求解相应分布方程；但本节寻求较简单的解以说明基本概念，故限制于 $d\geq 3$ 的随机 d 正则图。给定 d,β,q，参数 a 满足自洽方程

$$a=\frac{[1-(1-e^{-\beta})a]^{d-1}}{[1-(1-e^{-\beta})a]^{d-1}+(q-1)[1-(1-e^{-\beta})(1-a)/(q-1)]^{d-1}}$$
$$=:\mathrm{RHS}(a;\beta,d,q).\tag{6.11}$$

把式 (6.9) 代入式 (6.7)，得到对应的 Bethe 自由熵：

$$\Phi_{\mathrm{Bethe}}(\beta)=\log\left\{(q-1)\left[1-(1-e^{-\beta})\frac{1-a}{q-1}\right]^{d}+[1-(1-e^{-\beta})a]^{d}\right\}$$
$$-\frac{d}{2}\log\left\{1-(1-e^{-\beta})\left[\frac{(1-a)^2}{q-1}+a^2\right]\right\}.\tag{6.12}$$

在最后的表达式中，可以将 Bethe 自由熵看作参数 a 的函数，同时记住，我们最终要在全局极

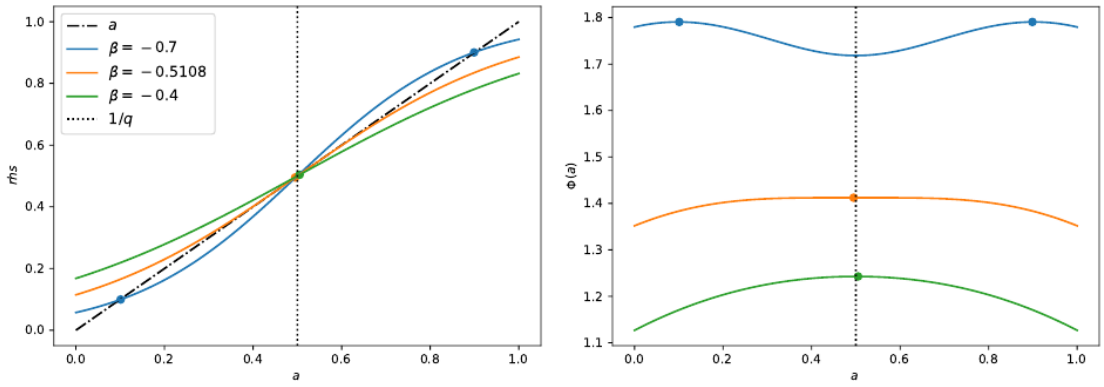


图 6.5.1: 5 正则图上二着色在若干逆温度 β 下的二阶（连续）相变。左图为式 (6.11) 右端随参数 a 的变化；右图为相同逆温度下的 Bethe 自由熵。标出的稳定不动点对应 Bethe 自由熵的局域极大值。

大值点处求值。

6.5.1 Ising 铁磁体，$q = 2$

图 6.5.1 绘出了给定度 d 和颜色数 q、若干逆温度 β 下，式 (6.11) 左右两端随 a 的变化，也绘出了 Bethe 自由熵关于 a 的函数。

当 $\beta = -0.4$（绿色曲线）时，式 (6.11) 的唯一不动点和式 (6.12) 的极大值都在 $a = 1/q$ 处，正是前面研究的顺磁不动点。当 $\beta = -0.7$（蓝色曲线）时，图景发生变化：$a = 1/q$ 在方程迭代下不稳定，对应 Bethe 自由熵的局域极小值；同时出现两个新的稳定不动点，对应 Bethe 熵的极大值。

额外的不动点在哪个逆温度出现？为此需要考察顺磁不动点的稳定性，即求顺磁不动点处导数 $\partial\,\mathrm{RHS}\,/\partial a|_{a=1/q} = 1$ 的位置：

$$1 = \left.\frac{\partial\,\mathrm{RHS}}{\partial a}\right|_{a=1/q} = -\frac{(d-1)(1-e^{-\beta})}{e^{-\beta}+(q-1)} \quad\Longrightarrow\quad \beta_{\mathrm{stab}} = -\log\left(1+\frac{q}{d-2}\right). \tag{6.13}$$

保持 $q = 2$ 而改变度 d，所有 d 下均可观察到相同图景：这正是 Curie–Weiss 模型中见过的从顺磁体到铁磁体的二阶相变。事实上，两模型的区别仅在于，Curie–Weiss 模型的相互作用图完全连接，此处则是 d 正则随机图。这给出了规则立方晶格上 Ising 模型解的 Bethe 近似。晶格当

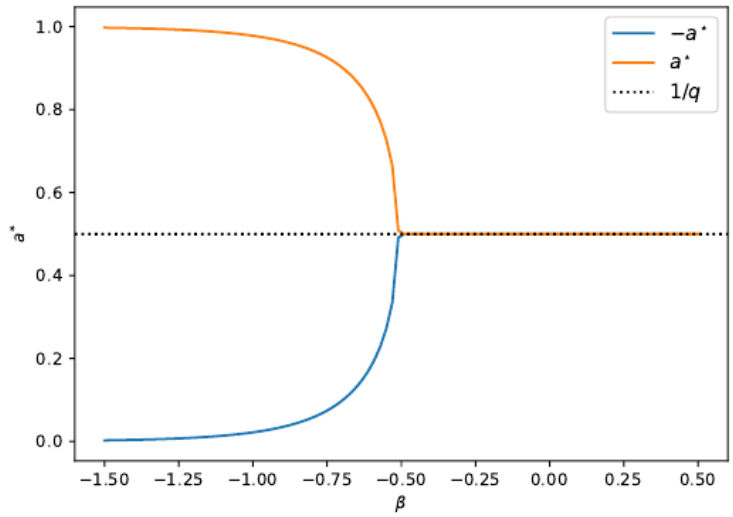


图 6.5.2: 5 正则图上二着色的磁化强度随逆温度 β 的变化。

然不是树，但若令随机图的度匹配 D 维立方晶格的配位数，则 $d = 2D$。当 $D = 1$（$d = 2$）时，$\beta_{\mathrm{stab}} = -\infty$。此时结果实际上精确，因为一维立方晶格就是链，是树图，因此 BP 解精确。对于 Onsager 著名的二维 Ising 模型精确解，$\beta_{\mathrm{Onsager}} = -\log(1+\sqrt{2}) = -0.881$，与 Bethe 近似 $\beta_{\mathrm{stab}}(d=4) = -0.693$ 相当接近。注意，这里的符号与文献相反，因为我们把正温度定义在着色（反铁磁）一侧；此外还有乘法因子 2，因为这里变量改变的能量成本为 1，而通常 Ising 模型中为 2。三维 Ising 模型尚无闭合形式的解，但临界温度已被数值计算到很高精度：$\beta_{3D} = -0.4433$，可与 Bethe 近似 $\beta_{\mathrm{stab}}(d=6) = -0.4055$ 比较，二者也十分接近。随着度增大，Bethe 近似越来越接近有限维数值。最终，当 $d \to \infty$ 并适当重标相互作用强度时，便精确恢复第一讲研究的 Curie–Weiss 解。读者将在课后习题中证明这一点。**译注：**以上数值沿用原文的着色能量与负 β 约定，不能直接与通常 Hamiltonian 约定下的临界逆温度混用；闭合链含回路，树上精确性的说法需按开链或热力学极限理解。

6.5.2 Potts 铁磁体，$q \geq 3$

当颜色数超过两种，即 $q \geq 3$ 时，会出现不同的行为，导致一阶相变。再次画出不动点方程和 Bethe 自由熵，见图 6.5.3。与前面一样，β_{stab} 标志着顺磁不动点 $1/q$ 失稳、对应 Bethe 熵极大值变为极小值的逆温度。然而，另一个稳定不动点会在 $\beta_s > \beta_{\text{stab}}$ 处出现，对应 Bethe 熵的局域极大值。新稳定不动点不连续出现的逆温度，在物理学中称为旋节温度 (spinodal temperature)。

存在多个稳定不动点、即式 (6.12) 的多个 Bethe 自由熵局域极大值时，必须比较其自由熵；较大者主导对应鞍点，因此给出正确解。 铁磁不动点 $a > 1/q$ 取代顺磁不动点成为 Bethe 熵全

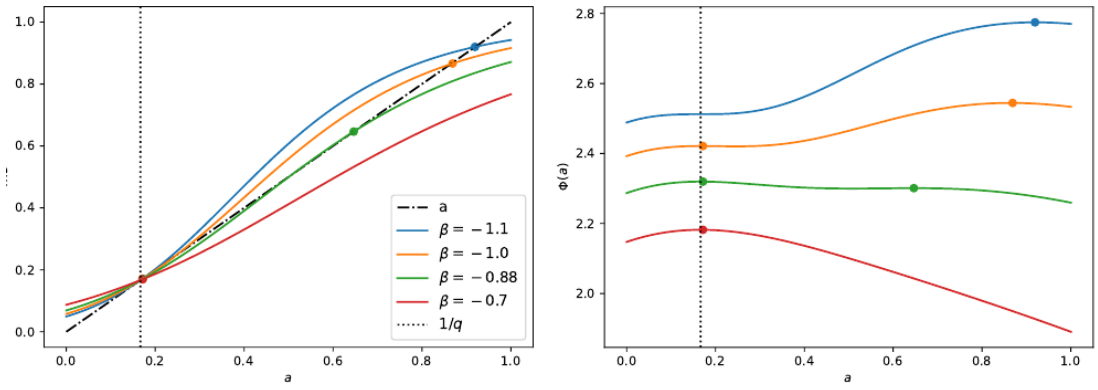


图 6.5.3: 5 正则图上六着色在若干逆温度 β 下的一阶（不连续）相变。左图为式 (6.11) 右端随参数 a 的变化；右图为相同逆温度下的 Bethe 自由熵。标出的稳定不动点对应 Bethe 自由熵的局域极大值。

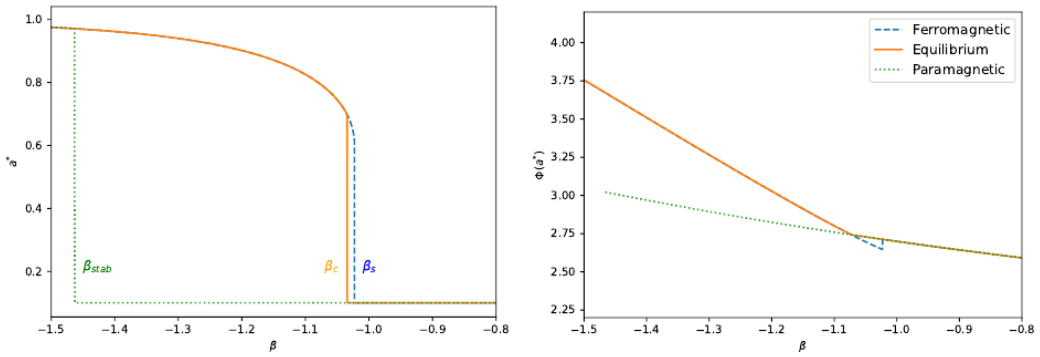


图 6.5.4: $q = 10, d = 5$ 时，磁化强度（左）和 Bethe 自由熵随逆温度 β 的变化。注意，颜色数 q 与上一图不同。图中 Ferromagnetic、Equilibrium、Paramagnetic 分别表示铁磁、平衡与顺磁分支。

局极大值的逆温度，记为 β_c，对应一阶相变。此时 $\beta_{\text{stab}} < \beta_c < \beta_s$，序参量 a 在 β_c 处不连续变化。而在 $q = 2$ 时，所见的是连续二阶相变：铁磁不动点的出现、对应自由熵成为全局极大值、顺磁不动点失稳都发生于同一温度。换言之，二阶相变中 $\beta_s = \beta_c = \beta_{\text{stab}}$。

了解铁磁不动点后，就能修正给定成本下着色数的结果，如图 6.5.5。这里需要作两点重要说明：

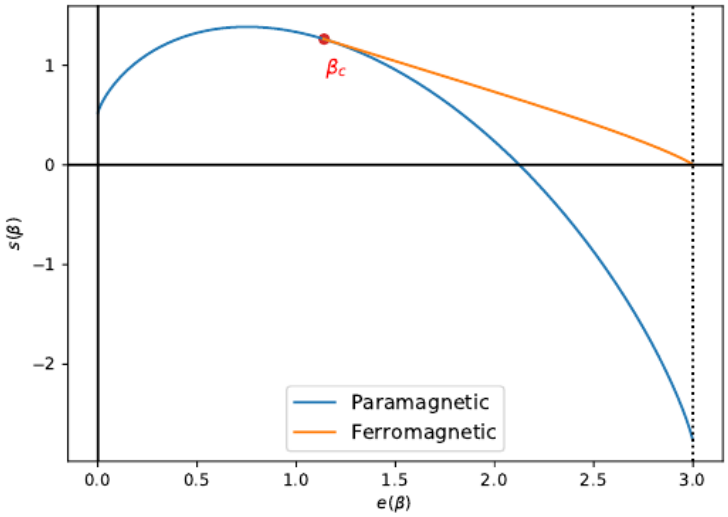


图 6.5.5: $q = 4$、平均度 $c = d = 6$ 时，图着色的熵随能量的变化，与图 6.4.1 的参数相同。Paramagnetic、Ferromagnetic 分别表示顺磁、铁磁分支。

- 随机图上由 BP 得到的结果在 $\beta < 0$ 时是精确的，含义是

$$\forall \varepsilon > 0, \qquad \Pr(|\Phi(\beta) - \Phi_{\text{Bethe}}(\beta)| < \varepsilon) \xrightarrow{N\to\infty} 1 \qquad \text{以高概率.} \tag{6.14}$$

  对于 $q = 2$，Dembo 与 Montanari 于 2010 年证明了这一点，见 Dembo et al. (2010b)，适用的稀疏随机图还超出了 d 正则图。对于 $q \geq 3$，Dembo、Montanari、Sly、Sun 于 2014 年在 d 正则图上证明了这一点，见 Dembo et al. (2014)。$\beta > 0$ 时，情形复杂得多，下文将讨论。

- 顺磁和铁磁不动点对有限大小正则图也是 BP 不动点，并非只在 $N \to \infty$ 时成立。但并非每个正则图在给定能量下都有相同的着色数，尤其是非随机正则图。上述相变仅在 $N \to \infty$ 极限存在，而 BP 不动点在有限 N 下已表现出所讨论的行为。这意味着 BP 忽略了部分有限大小效应，并在有限系统中也给出有趣的相变表征；严格地说，有限 N 的自由熵为解析函数，因此不存在这里所说的相变。

译注：上述严格性结论按原文给定的图系综与被选中自由熵分支理解；此处保留作者和年份，尚未与书末文献条目逐项联接核对。不能据此断言任意 BP 不动点在任意图上均精确。

6.6 回到反铁磁（$\beta > 0$）情形

现在回到反铁磁情形 $\beta > 0$，其中 $\beta \to \infty$ 对应随机稀疏图上的原始着色问题。目标是求出平均度的条件，使图以高概率可着色或不可着色。还希望知道，在以高概率存在着色的相中，着色数有多少，即 $s(e = 0)$ 的值。

前面已计算顺磁不动点 $\chi_s^{i\to j} \equiv 1/q$ 的熵 $s(e)$。可以看到，对应的 Bethe 自由熵等于所谓退火自由熵。为定义这个量，先回顾所考虑的一般概率分布：

$$P(\{s_i\}_{i=1}^N) = \frac{1}{Z_G} \prod_{i=1}^{N} g_i(s_i) \prod_{a=1}^{M} f_a(\{s_i\}_{i\in\partial a}). \tag{6.15}$$

自由熵 $\Phi_G = N^{-1}\log Z_G$ 显式依赖于图 G。我们预期自由熵自平均，即集中于其均值附近：

$$\forall \varepsilon > 0, \qquad \Pr(|\Phi_G - \mathbb{E}_G[\Phi_G]| > \varepsilon) \xrightarrow{N\to\infty} 0. \tag{6.16}$$

因此，当 $N \to \infty$ 时，计算 Φ_G 与计算 $\mathbb{E}_G[\Phi_G]$ 应给出相同结果。定义

$$\text{淬火自由熵} \quad \Phi_{\text{quench}} \equiv \mathbb{E}_G\left[\frac{1}{N}\log Z_G\right],$$
$$\text{退火自由熵} \quad \Phi_{\text{anneal}} \equiv \frac{1}{N}\log(\mathbb{E}_G[Z_G]).$$

粗看之下，也许会期待 $(\mathbb{E}[\log Z] - \log \mathbb{E}[Z])/N \to 0$，但事实常常并非如此。当 $N \to \infty$ 时，配分函数为 $Z = O(\exp N)$，而集中性只对 $N^{-1}\log Z$ 成立。退火自由熵可能受图 G 的罕见实例主导。下面给出简单例子。

考虑人为构造的问题，其中

$$Z_G = \begin{cases} e^N, & \text{概率为} 1 - e^{-N}, \\ e^{3N}, & \text{概率为} e^{-N}. \end{cases}$$

淬火平均与退火平均分别为

$$\mathbb{E}_G\left[\frac{1}{N}\log Z_G\right] = (1 - e^{-N}) + 3e^{-N} = 1 + 2e^{-N} \to 1,$$
$$\frac{1}{N}\log(\mathbb{E}_G[Z_G]) = \frac{1}{N}\log(e^N - 1 + e^{2N}) = 2 + \frac{1}{N}\log(1 + e^{-N} - e^{-2N}) \to 2.$$

可见，淬火熵反映典型值，而退火熵受指数罕见值影响，可能完全误导我们对典型实例性质的判断。一般而言，$\log(\cdot)$ 是凹函数，Jensen 不等式给出 $\Phi_{\text{anneal}} \geq \Phi_{\text{quench}}$，故退火自由熵至少提供上界。当然，$\Phi_{\text{anneal}}$ 通常比 Φ_{quench} 容易计算得多。

对于着色问题，设 $G(N, M)$ 表示具有 N 个节点、从所有可能边中随机选取 M 条边的随机图。退火自由熵由下式得到：

$$\begin{aligned} \mathbb{E}_{G(N,M)}[Z_G(\beta)] &= q^N \mathbb{E}_{\{s_i\}_{i=1}^N} \mathbb{E}_{G(N,M)}\left[e^{-\beta\sum_{(ij)\in E}\delta_{s_i,s_j}}\right] \\ &= q^N \left[\underbrace{e^{-\beta}\frac{1}{q} + \left(1 - \frac{1}{q}\right)}_{\text{一条边的自由熵}}\right]^M. \end{aligned}$$

这里利用了随机图中边相互独立，以及当 $\beta > 0$ 时，平均贡献由各种颜色出现次数大致相等的着色主导。因此，退火熵为正，并在以下平均度处降为零：

$$c_{\text{ann}}(\beta) = -\frac{2\log q}{\log[1 - (1 - e^{-\beta})/q]}. \tag{6.17}$$

注意，退火自由熵与顺磁不动点对应的 Bethe 自由熵相等：$\Phi_{\text{anneal}} = \Phi_{\text{Bethe}}|_{\chi\equiv 1/q}$。**译注：** 固定边数的 $G(N, M)$ 简单图中边并不严格独立；上式将平衡颜色的主导阶计算写成等号，不能据本段认作任意有限 N 精确恒等式。括号内是单边权重的平均，原文将其标为“自由熵”，照录。

问题是：退火 / 顺磁自由熵对所有平均度 c 和逆温度 $\beta > 0$ 都正确吗？遗憾的是，答案是否定的。例如，原文称在 $\beta \to 0$ 时，Coja-Oghlan (2013) 证明：当平均度严格小于 $\Phi_{\text{anneal}}(\beta \to \infty)$

变负的位置 $c_{\mathrm{ann}}(\beta\to\infty)$ 时，所有合法着色就已以高概率消失。这意味着 Φ_{anneal} 不可能一直等于淬火自由熵，直到 c_{ann}。**译注：**这里的 $\beta\to 0$ 是源 PDF 的可见文字；同句随后谈论合法着色与 $\beta\to\infty$，两者不一致，保留并待核对原引文。

顺磁不动点 $\chi_s^{i\to j}\equiv 1/q$ 会出现什么问题？首先应问，信念传播在大型随机图上是否收敛到这个不动点。它是否稳定？也就是说，若初始化 $\chi_s^{i\to j}=1/q+\varepsilon_s^{i\to j}$（因归一化有 $\sum_s\varepsilon_s^{i\to j}=0$），BP 会收敛回 $\chi_s^{i\to j}\equiv 1/q$ 吗？可以在一张大图上实现迭代，直接尝试。

更精确的计算方法是作线性稳定性分析。令 $\theta=1-e^{-\beta}$，在不动点 $\chi\equiv 1/q$（等价于 $\varepsilon_{s_k}^{k\to j}\equiv 0$）附近作一阶 Taylor 展开：

$$\chi_{s_j}^{j\to i}(t+1)=\frac{1}{q}+\sum_{k\in\partial j\setminus i}\sum_{s_k}\left.\frac{\partial\chi_{s_j}^{j\to i}(t+1)}{\partial\chi_{s_k}^{k\to i}(t)}\right|_{\chi\equiv 1/q}\varepsilon_{s_k}^{k\to j}.$$

注意，

$$\frac{1}{q}=\frac{1}{Z^{j\to i}|_{\chi\equiv 1/q}}\prod_{k\in\partial j\setminus i}\left(1-\theta\frac{1}{q}\right)=\frac{(1-\theta/q)^{d_j-1}}{Z^{j\to i}|_{\chi\equiv 1/q}},$$

$$Z^{j\to i}\big|_{\chi\equiv 1/q}=q\left(1-\frac{\theta}{q}\right)^{d_j-1}. \tag{6.18}$$

故

$$\begin{aligned}\left.\frac{\partial\chi_{s_j}^{j\to i}(t+1)}{\partial\chi_{s_k}^{k\to j}(t)}\right|_{\chi\equiv 1/q}&=\frac{1}{Z^{j\to i}}\frac{\partial}{\partial\chi_{s_k}^{k\to j}(t)}\left[\prod_{\ell\in\partial j\setminus i}(1-\theta\chi_{s_j}^{\ell\to j}(t))\right]\Bigg|_{\chi\equiv 1/q}\\&\quad-\frac{1}{(Z^{j\to i})^2}\prod_{\ell\in\partial j\setminus i}(1-\theta\chi_{s_j}^{\ell\to j}(t))\left.\frac{\partial Z^{j\to i}}{\partial\chi_{s_k}^{k\to j}(t)}\right|_{\chi\equiv 1/q}\\&=\delta_{s_j,s_k}\frac{-\theta(1-\theta/q)^{d_j-2}}{Z^{j\to i}|_{\chi\equiv 1/q}}-\frac{(1-\theta/q)^{d_j-1}}{(Z^{j\to i}|_{\chi\equiv 1/q})^2}[-\theta(1-\theta/q)^{d_j-2}]\\&=-\delta_{s_j,s_k}\frac{\theta}{q-\theta}+\frac{\theta}{q(q-\theta)}.\end{aligned}$$

译注：最初 Taylor 展开分母中的消息上标为 $k\to i$，后续导数为 $k\to j$；按原文分别保留。

为继续推导，定义 $q\times q$ 矩阵 T：

$$T_{jk}=\begin{cases}a:=\dfrac{\theta(1-q)}{q(q-\theta)}, & j=k,\\ b:=\dfrac{\theta}{q(q-\theta)}, & j\neq k,\end{cases}\qquad\Longrightarrow\quad T=\begin{pmatrix}a & b & \cdots & b\\ b & a & \ddots & \vdots\\ \vdots & \ddots & \ddots & b\\ b & \cdots & b & a\end{pmatrix}. \tag{6.19}$$

矩阵 T 有 $q-1$ 重简并本征值

$$\lambda_{\max}=a-b=-\frac{\theta}{q-\theta}\quad\Longrightarrow\quad\begin{cases}<0, & \beta>0,\\ >0, & \beta<0,\end{cases}$$

对应本征向量如 $[+1,-1,0,\ldots,0]^{\mathsf{T}}$，另有一个零本征值。因此，关于 ε 的 BP 方程线性展开为

$$\varepsilon_{s_j}^{j\to i}(t+1)=\sum_{k\in\partial j\setminus i}\sum_{s_k}T_{s_j,s_k}\varepsilon_{s_k}^{k\to j}(t). \tag{6.20}$$

现在，对度分布为 p_k、平均度为 c 的随机图系综，定义剩余度分布 $\widetilde{p}_k = (k+1)p_{k+1}/c$。$\widetilde{p}_k$ 表示随机选取一条边时，其端点除了所选边之外还有 k 条边，即端点的度为 $k+1$ 的概率。类似地，以 $\widetilde{c} = \sum_k k\widetilde{p}_k$ 表示平均剩余度。于是

$$\langle \varepsilon(t+1)\rangle = \widetilde{c}\lambda_{\max}\langle \varepsilon(t)\rangle, \tag{6.21}$$

其中 $\langle\cdot\rangle$ 表示对边取平均。$\widetilde{c}\lambda_{\max} = 1$ 处发生相变，决定 $\lim_{t\to\infty}\langle\varepsilon(t+1)\rangle$ 发散至无穷还是收敛于零：

$$\widetilde{c}\lambda_{\max} = \frac{-\widetilde{c}(1-e^{-\beta_{\mathrm{stab}}})}{q-(1-e^{-\beta_{\mathrm{stab}}})} = 1 \quad\Longrightarrow\quad \beta_{\mathrm{stab}} = -\log\left(1+\frac{q}{\widetilde{c}-1}\right). \tag{6.22}$$

这就是先前为 $\beta<0$ 铁磁解算出的稳定性转变。对于 $\beta>0$，$\lambda_{\max}<0$，相应不稳定性表现为每次并行迭代在不同颜色间振荡。二部图上可以出现这种振荡：图的一侧取一种颜色，另一侧取另一种颜色。但随机图有大量奇、偶长度回路，这种二着色解与之不相容。因此，温度 β_{stab} 对反铁磁情形 $\beta>0$ 不会产生重要影响。**译注：**原文将非平凡本征值记为 $\lambda_{\max}$；当 $\beta>0$ 时它为负，代数最大本征值实际是另一个零本征值。此处须理解为归一化扰动子空间内的本征值。线性化失稳不等同于完整概率消息真的无界增长；均值递推和后文方差递推均使用随机图 / 分支独立的近似条件。

有可能扰动均值 $\langle\varepsilon\rangle\to 0$，而方差 $\langle\varepsilon^2\rangle \nearrow \infty$ 吗？考察

$$\begin{aligned}\left\langle (\varepsilon_{s_j}^{j\to i}(t+1))^2\right\rangle &= \Bigg\langle \sum_{k\in\partial j\setminus i}\left[\sum_{s_k} T_{s_j,s_k}\varepsilon_{s_k}^{k\to j}(t)\right]^2 \\ &\qquad + \underbrace{\sum_{\substack{k,\ell\in\partial j\setminus i\\ k\neq\ell}}\left[\sum_{s_k} T_{s_j,s_k}\varepsilon_{s_k}^{k\to j}(t)\right]\left[\sum_{s_\ell} T_{s_j,s_\ell}\varepsilon_{s_\ell}^{\ell\to j}(t)\right]}_{=0,\ \text{因邻居独立且}\langle\varepsilon_{s_k}^{k\to j}\varepsilon_{s_\ell}^{\ell\to j}\rangle=0}\Bigg\rangle \\ &= \widetilde{c}\left\langle\left[\sum_{s_k} T_{s_j,s_k}\varepsilon_{s_k}^{k\to j}(t)\right]^2\right\rangle.\end{aligned}$$

因此，方差由 T 的最大本征值 $\lambda_{\max}$ 决定：

$$\mathrm{Var}(t+1) = \widetilde{c}\lambda_{\max}^2\,\mathrm{Var}(t). \tag{6.23}$$

于是图着色问题可分两种情形：

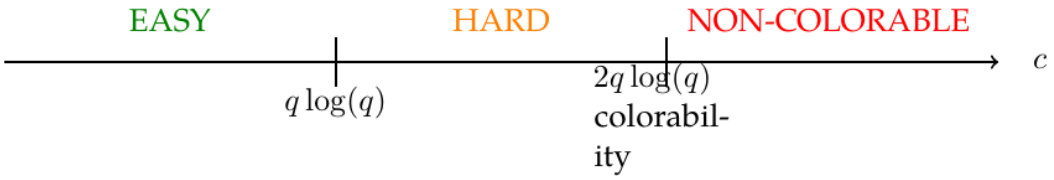
- 当 $\widetilde{c} < (q-\theta)^2/\theta^2$ 时，BP 收敛回 $\chi\equiv 1/q$。特别在 $\beta\to\infty$ 时，
$$\widetilde{c}_{\mathrm{KS}} = \frac{(q-\theta)^2}{\theta^2} \to (q-1)^2. \tag{6.24}$$
- 当 $\widetilde{c} > (q-\theta)^2/\theta^2$ 时，BP 远离 $1/q$，且实际上不收敛。

KS 缩写来自 Kesten 与 Stigum (1967) 的工作；物理学中，这一转变与 de Almeida 和 Thouless (1978) 的工作有关。

对于 Erdős–Rényi 随机图，平均度与平均剩余度相等，即 $\widetilde{c}=c$。当 $q=3, \beta\to\infty$ 时，$c_{\mathrm{KS}}(q=3) = 4 < c_{\mathrm{ann}}(q=3) = 5.4$。此时 c_{KS} 也小于 Coja-Oghlan (2013) 给出的可着色阈值

上界。在平均度 $c > 4$ 时，BP 方程不再收敛，需要基于副本对称破缺的另一种方法理解其行为。有趣的是，已存在可证明对所有 $c < 4.03$ 找到合法三着色的算法，见 Achlioptas and Moore (2003)；这甚至略高于阈值 $c_{\mathrm{KS}}(q = 3) = 4$。

当 $q \geq 4, \beta \to \infty$ 时，$c_{\mathrm{KS}} > c_{\mathrm{ann}}$，上述不稳定性不能解释可着色区域内出了什么问题。理解这一现象的重要动机来自大颜色数 q 时的算法图景：退火可着色上界按 $2q \log q$ 缩放，概率下界（例如 Coja-Oghlan and Vilenchik, 2013）说明，这确实是可着色阈值的正确尺度。但对于可证明找到合法着色的多项式时间算法，我们只知道能工作到度 $q \log q$ 的算法，见 Achlioptas and Coja-Oghlan (2008)，即只覆盖可着色区域的一半。设计能在平均度 $(1+\epsilon)q \log q$ 下找到合法着色的可处理算法，是一个长期未解决的问题。可着色区域后半部分发生了什么，将在后续讲义中阐明。



图示中 EASY、HARD、NON-COLORABLE 分别为容易、困难和不可着色区域，横轴为平均度 c；$q \log q$ 与 $2q \log q$ 表示所讨论的大 q 尺度。**译注：** 这里“不收敛”和“长期未解决”等叙述均沿用源讲义的时间与分析范围；局部线性失稳本身不排除其他初始条件、非平行更新或其他不动点的收敛。对任意 $q \geq 4$ 的阈值比较及严格算法保证仍需结合所引文献的精确条件，不以该图作为一般计算复杂性证明。

6.7 习题

习题 6.1：Bethe 自由熵

1. 从讲义中推导的一般 Bethe 自由熵密度公式

$$\Phi_{\mathrm{Bethe}}^{\mathrm{general}} = \frac{1}{N}\sum_{i=1}^{N} \log Z^i + \frac{1}{N}\sum_{a=1}^{M} \log Z^a - \frac{1}{N}\sum_{ia} \log Z^{ia}, \tag{†}$$

$$Z^i = \sum_s g_i(s) \prod_{a \in \partial i} \psi_s^{a \to i},$$

$$Z^a = \sum_{\{s_i\}_{i \in \partial a}} f_a(\{s_i\}_{i \in \partial a}) \prod_{i \in \partial a} \chi_{s_i}^{i \to a},$$

$$Z^{ia} = \sum_s \psi_s^{a \to i} \chi_s^{i \to a},$$

证明图着色的 Bethe 自由熵密度可写为

$$\Phi_{\mathrm{Bethe}}^{\mathrm{coloring}} = \frac{1}{N}\sum_{i=1}^{N} \log Z^{(i)} - \frac{1}{N}\sum_{(ij) \in E} \log Z^{(ij)},$$

$$Z^{(i)} = \sum_s \prod_{k \in \partial i} [1 - (1 - e^{-\beta})\chi_s^{k \to i}],$$

$$Z^{(ij)} = 1 - (1 - e^{-\beta}) \sum_s \chi_s^{i \to (ij)} \chi_s^{j \to (ij)}.$$

习题 6.2：由信念传播得到完全连接极限

本题旨在说明，当平均度很大时，信念传播的解恢复完全连接极限，特别是恢复式 (1.22) 中的 “完全连接” 空腔法结果。从 Potts 铁磁模型出发，并取 $q = 2$，以联系第 1.4 节的铁磁解。

1. 首先检验能否恢复平均场自洽方程。将第 6.5 节推导的递推关系取 $q = 2$，记 $\chi_{\pm} = (1 \pm m)/2$，证明 BP 递推的不动点可写为

$$m = -\frac{(\cosh\frac{\beta}{2} + m\sinh\frac{\beta}{2})^{d-1} - (\cosh\beta - m\sinh\frac{\beta}{2})^{d-1}}{(\cosh\frac{\beta}{2} + m\sinh\frac{\beta}{2})^{d-1} + (\cosh\frac{\beta}{2} - m\sinh\frac{\beta}{2})^{d-1}}. \tag{6.25}$$

   利用 $\operatorname{atanh} x = \frac{1}{2}\log\frac{1+x}{1-x}$，证明得到

$$m = -\tanh\left[(d-1)\operatorname{atanh}\left(m\tanh\frac{\beta}{2}\right)\right]. \tag{6.26}$$

2. 取大 d 极限，使用 $\beta = -2\beta_{\mathrm{MF}}/d$。为什么恢复完全连接模型需要这一重标？证明它确实给出平均场方程

$$m = \tanh(\beta_{\mathrm{MF}} m). \tag{6.27}$$

另一种方法是直接考察自由熵，对 Bethe 自由熵取大连接度极限，直接恢复完全连接模型的自由熵表达式。

1. 证明按照信念传播，Bethe 自由熵为

$$\Phi(\beta, m) = \log\left\{\left[1 - (1-e^{-\beta})\frac{1+m}{2}\right]^d + \left[1 - (1-e^{-\beta})\frac{1-m}{2}\right]^d\right\} - \frac{d}{2}\log\left\{1 - (1-e^{-\beta})\frac{1}{2}[1+m^2]\right\}.$$

2. 再次取 $\beta = 2\beta_{\mathrm{MF}}/d$。证明，当 $d \to \infty$ 时，在 d 的主导阶恢复式 (1.22)。提示：先将第一行对数中的表达式改写为

$$\left[1 - (1-e^{-\beta})\frac{1 \pm m}{2}\right]^d = e^{d\log[1-(1-e^{-(2/d)\beta_{\mathrm{MF}}})(1\pm m)/2]}. \tag{6.28}$$

   但注意，会多出平凡项 $\beta_{\mathrm{MF}}/2$。解释它为何出现。

译注： 式 (6.25) 分子第二项的 $\cosh\beta$ 为原文写法，其他相应项为 $\cosh(\beta/2)$；此外递推的整体负号与大度极限需要核对。题目前半采用 $\beta = -2\beta_{\mathrm{MF}}/d$，后半却写正号 $\beta = 2\beta_{\mathrm{MF}}/d$，并在式 (6.28) 沿用正号，故不应默认为同一个铁磁极限。全部原式保留，不代替作者补写答案。

习题 6.3：随机图匹配问题的信念传播

考虑稀疏随机图上的匹配问题，使用前次作业中的图模型表示。

1. 写出能够估计下列概率分布边缘分布的信念传播方程：

$$P(\{S_{(ij)}\}_{(ij)\in E}) = \frac{1}{Z(\beta)} \prod_{(ij)\in E} e^{\beta S_{(ij)}} \prod_{i=1}^{N} \mathbb{I}\left(\sum_{j\in\partial i} S_{(ij)} \le 1\right).$$

   注意，匹配问题中，原图的节点扮演图模型中的因子节点，原图的边承载图模型中的变量节点。

2. 写出对应 Bethe 自由熵，以估计 $\log Z(\beta)$。利用前次作业的结果，提出如何估计给定随机生成大图 G 上给定大小的匹配数。

3. 考虑 d 正则随机图，对若干 d 画出匹配数随匹配大小的变化。评论所得结果：是否符合预期？若不符合，解释差别。

第二部分：概率推断

7 去噪、估计与贝叶斯最优推断

> 如果一个事件可由 n 种不同原因产生，那么在给定该事件时，各原因存在的概率之比，等于给定各原因时该事件发生的概率之比；每个原因存在的概率，等于给定该原因时事件发生的概率，除以给定各个原因时事件发生概率的总和。
>
> Pierre Simon de Laplace，1774

7.1 Bayes–Laplace 逆问题

本章讨论如何估计或学习一个不能直接获知、只能通过间接含噪测量了解的量。从信号处理、贝叶斯统计或信息论出发，对问题的理解方式有所不同，但归根结底都是从数据中分离信号与噪声。

具体而言，假设未知信号 x（可以是向量、标量、矩阵等）由已知分布 $P_X(x)$ 生成。我们想知道这个信号，估计其取值。然而，获得的并不是 x，而是经由某个已知特性的含噪过程得到的测量值 y。换言之，有 $X \to Y$，且

$$X \sim P_X(x), \qquad\qquad Y \sim P_{Y|X}(y \mid x), \tag{7.1}$$

目标是尽可能好地恢复 x。

这就是贝叶斯估计的设定。P_X 称为“先验”分布，说明在测量之前先验地知道变量 X 的什么信息。$P_{Y|X}$ 给出 x 已知时得到测量结果 y 的概率。给定 y 而视为 x 的函数时，$L = (x; y) = P_{Y|X}(y, x)$ 称为 x 的似然。然而，真正关心的是测得 y（数据）后 x（信号）的值，这由给定 Y 时 X 的后验概率 $P_{X|Y}(x, y)$ 描述。遵循 Laplace 和 Bayes 在 18 世纪末给出的方向，写出著名的 Bayes 公式：

$$P_{X|Y}(x, y) = \frac{P_{Y|X}(x, y) P_X(x)}{P_Y(y)}. \tag{7.2}$$

因此，后验等于 X 的先验概率 $P_X(x)$ 乘以似然 $P_{Y|X}(x,y)$，再除以 “证据”$P_Y(y)$，后者仅为归一化常数。对连续变量，同样的公式可用概率密度写为

$$P_{X|Y}(x,y)=\frac{P_{Y|X}(x,y)P_X(x)}{P_Y(y)}. \tag{7.3}$$

译注： 原文对条件分布有时用 $(y\mid x)$，有时将 (x,y) 或 (y,x) 作为自变量对列出；本章保持可见原式的次序，不将这些排版记法默认为同一个有序二元函数。

这一贝叶斯设定并非完全一般! 许多估计问题中，我们往往不知道 P_X，有时也不知道 $P_{Y|X}$，这使形式体系的应用变得棘手，并引发了频率派与贝叶斯统计学家之间的长期争论。但本章暂且搁置这些问题，只讨论已知上述分布、可以放心使用贝叶斯统计的情形。信息论与纠错、信号处理、去噪等领域有许多具体问题满足这一条件，足够我们研究一段时间。更复杂的情形留待后文。

7.2 标量估计

7.2.1 后验分布

考虑三个具体问题，其 “真值” 为标量 x^*，生成方式分别为

1. Rademacher 随机变量：以概率 $1/2$ 分别取 $X=\pm1$。
2. 零均值、单位方差高斯随机变量：$X\sim\mathcal{N}(x;0,1)$。
3. Gauss–Bernoulli 随机变量：以概率 $1/2$ 为零，否则为零均值、单位方差高斯变量，即 $X\sim\mathcal{N}(x;0,1)/2+\delta(x)/2$。

重点考虑含高斯噪声的测量。给定 n 次测量

$$y_i=x^*+\sqrt{\Delta}\,z_i,\qquad i=1,\dots,N, \tag{7.4}$$

其中 $z_i\sim\mathcal{N}(0,1)$ 是零均值、单位方差的标准高斯噪声。根据 Bayes 公式，对 x^* 的估计所用的后验概率为

$$P_{X|Y}(x,y)=\frac{1}{P_Y(y)}\frac{1}{(2\pi\Delta)^{N/2}}e^{-\sum_i(y_i-x)^2/(2\Delta)}P_X(x). \tag{7.5}$$

后验包含关于未知量 x^* 的推断所能知道的全部信息。**译注：** 原文先称测量次数为 n，公式则用 N；后验的乘积形式按独立高斯测量噪声理解，但本句未另外列出独立性条件。

例如，在 Rademacher 情形，若给定五个测量值

$$1.04431591,\quad 2.55352006,\quad 1.43665582,\quad 1.37069702,\quad 0.77697312, \tag{7.6}$$

则很可能 $x^*=1$，而非 $x^*=-1$。有多大可能？显式计算后验得

$$P_{X|Y}^{\text{Rademacher}}(x\mid y)=\frac{1}{1+e^{-2x\sum_{i=1}^N y_i/\Delta}}=\sigma\left(2x\sum_{i=1}^N\frac{y_i}{\Delta}\right), \tag{7.7}$$

其中 σ 为 sigmoid 函数。由此得出，$x^*=1$ 的概率大于 0.999，所以确实很有把握。这一数值的意思是：若多次重复这种实验，当测得这样的 y 时，不到千分之一的情形来自 $x^*=-1$。

再看更困难的高斯例子。x^* 从高斯分布随机选取，给定十次测量：

$$\begin{aligned}&0.04724576,\quad 1.26855971,\quad -0.19887457,\quad 1.09534511,\quad -1.46442807,\\&0.44767123,\quad 2.6244575,\quad 1.94488421,\quad 0.58953688,\quad 0.572018.\end{aligned}\tag{7.8}$$

显式计算得到的后验本身也是高斯分布：

$$P_{X|Y}^{\text{Gaussian}}(x \mid y) = \mathcal{N}\left(x; \frac{\sum_{i=1}^{N} y_i}{N+\Delta}, \frac{\Delta}{N+\Delta}\right). \tag{7.9}$$

这一数据集的后验分布见图 7.2.1，是均值约 0.630、方差约 0.091 的高斯分布。实际真值为 $x^* = 0.67$。

最后考虑第三个例子。此时后验略为复杂：

$$\begin{aligned}P_{X|Y}^{\text{Gauss-Bernoulli}}(x \mid y) = {}& \frac{\delta(x)}{1+\sqrt{\frac{\Delta}{N+\Delta}}\exp\left[\frac{(\sum_{i=1}^{N} y_i)^2}{2\Delta(N+\Delta)}\right]}\\&+\frac{\mathcal{N}\left(x; \frac{\sum_{i=1}^{N} y_i}{N+\Delta}, \frac{\Delta}{N+\Delta}\right)}{1+\sqrt{\frac{N+\Delta}{\Delta}}\exp\left[-\frac{(\sum_{i=1}^{N} y_i)^2}{2\Delta(N+\Delta)}\right]}.\end{aligned}\tag{7.10}$$

我们从 Gauss–Bernoulli 分布随机选取 x^* 并进行实验，给定十次测量：

$$\begin{aligned}&0.99978688,\quad 1.7956116,\quad -0.43158072,\quad 3.07234211,\quad 1.11920946,\\&0.53248943,\quad 0.80011329,\quad -0.52783428,\quad 0.40378413,\quad -0.00223177.\end{aligned}\tag{7.11}$$

后验见图 7.2.2。这里 $x^* = 0.8$，非零的后验概率为 0.8233787142909471。 **译注：**第二幅图注原

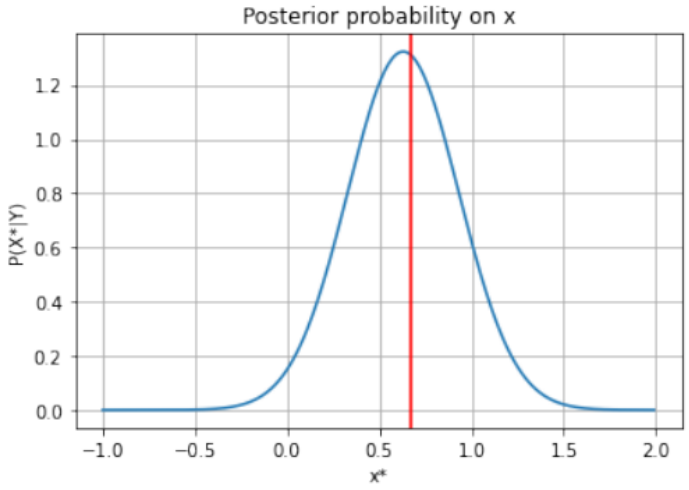


图 7.2.1: 高斯先验例子、数据 (7.8) 对应的后验分布。红色竖线标出真值 x^*。

文称“高斯先验”，正文实际为 Gauss–Bernoulli 混合先验，图注照录。数值例子的噪声参数未在相邻文字中另行给出，所报概率和均值不可据此泛化到任意 Δ。

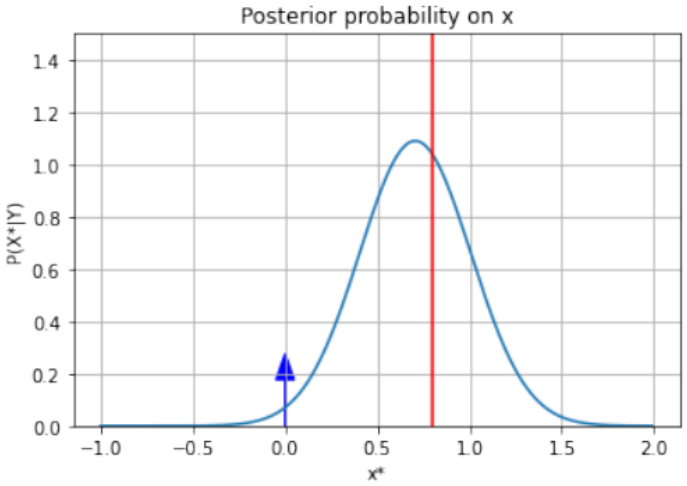


图 7.2.2: 高斯先验例子、数据 (7.11) 对应的后验分布。注意蓝色箭头表示的点质量分量，以及高斯分量；红线标出真值 x^*。

7.2.2 点估计推断：MAP、MMSE 等

我们往往不只关心后验分布，而是想对未知 x^* 给出某个具体估计：给出一个数，作出最佳猜测！这样的估计记为 $\widehat{x}(y)$，它应是数据 y 的函数，输出一个理想情况下尽量接近真值 x^* 的数。最先想到的是取最可能值，即后验分布的 “众数”，称为最大后验估计：

$$\widehat{x}_{\mathrm{MAP}}(y) := \operatorname*{argmax}_x P_{X|Y}(x, y). \tag{7.12}$$

MAP 是一种默认估计量，在许多情形中都会被选用，尤其因为它通常容易计算。

然而，至少在数据量有限时，它未必总是最佳估计量。例如，若后验形状像图中那样不规则，$\widehat{x}_{\mathrm{MAP}}$ 还合理吗？需要给出定义 “最佳” 估计量的方法。具体选择取决于如何定义 “误差”。例如，

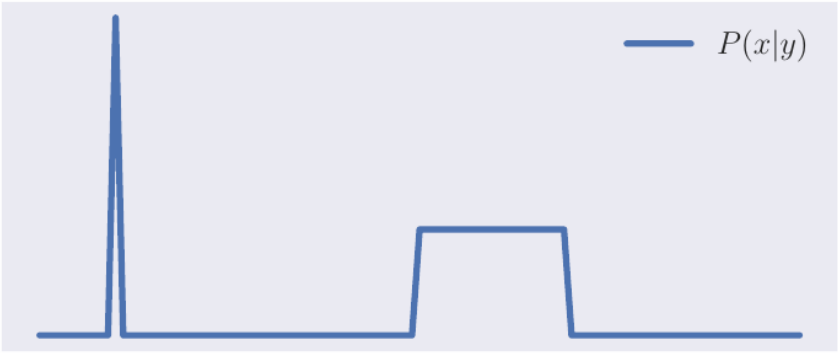


图 7.2.3: 形状不规则的后验。

可以选择最小化平方误差 $(\widehat{x}(y) - x^*)^2$ 或绝对误差 $|\widehat{x}(y) - x^*|$。若 x^* 离散，也可能更关心最小化取错值的概率，采用 $1 - \delta_{\widehat{x}(y),x^*}$。目标不同，应使用的估计量也会不同。

考虑给定估计量的期望误差。形式上，将损失函数 $\mathcal{L}(\widehat{x}(y), x^*)$ 对信号与测量的联合分布取

平均，定义为 “风险”。它称为平均后验风险，因为确实是后验风险的平均：

$$\mathcal{R}^{\text{averaged}}(\widehat{x}) = \mathbb{E}_{x^*,y}[\mathcal{L}(\widehat{x}, x^*)] = \int P_{X,Y}(x^*, y)\, dx^* dy\, \mathcal{L}(\widehat{x}(y), x^*), \tag{7.13}$$

$$= \int dy\, P_Y(y) \int P_{X|Y}(x^*, y)\, dx^* \mathcal{L}(\widehat{x}(y), x^*), \tag{7.14}$$

$$= \mathbb{E}_Y[\mathcal{R}^{\text{posterior}}(\widehat{x}, y)]. \tag{7.15}$$

当然，目标是最小化这一风险。其最小值，也就是平均而言可能获得的 “最佳” 误差，称为 Bayes 风险：

$$\mathcal{R}^{\text{Bayes}} = \min_{\widehat{x}} \mathcal{R}^{\text{averaged}}(\widehat{x}). \tag{7.16}$$

目标有两个：知道最佳可能误差即 Bayes 误差是多少，以及知道如何达到它，即找出实现 Bayes 风险的贝叶斯最优估计量。这一思路对平方损失给出如下定理。

定理 10 (MMSE 估计量)**.** *平方误差的最优估计量称为最小均方误差（MMSE）估计量，由后验均值给出：*

$$\widehat{x}_{\text{MMSE}}(y) = \mathbb{E}_{X|Y}(x, y). \tag{7.17}$$

最小均方误差由后验分布下的方差给出：

$$\text{MMSE} := \min_{\widehat{x}} \mathcal{R}^{\text{Bayes}}(y, \widehat{x}(\cdot)) = \int dx^* dy\, P_{X|Y}(x^*, y)(\mathbb{E}_{X|Y}(x, y) - x^*)^2$$

$$= \text{Var}_{P_{X|Y}}[X]. \tag{7.18}$$

译注： 式 (7.18) 原文把后验条件风险、对 y 的积分和 Bayes 风险写在一起；若对 y 积分通常还需 $P_Y(y)$，而固定 y 的最优后验风险才等于该后验方差。原公式保留，不将平均风险与条件风险混为一谈。

证明. 考虑平方损失的后验风险：

$$\mathcal{R}^{\text{Posterior}}(y, \widehat{x}(\cdot)) = \int P_{X|Y}(x^*, y)(\widehat{x}(y) - x^*)^2\, dx^*. \tag{7.19}$$

给定 y 后，$\widehat{x}$ 只是标量，即一个数。因此可对 $\widehat{x}$ 求导以获得最小值：

$$\frac{\partial}{\partial \widehat{x}} \mathcal{R}^{\text{Posterior}}(y, \widehat{x}(\cdot)) = 2 \int P_{X|Y}(x^*, y)(\widehat{x}(y) - x^*)\, dx^* = 0, \tag{7.20}$$

$$\widehat{x}(y) = \int P_{X|Y}(x^*, y) x^*\, dx^* = \int P_{X|Y}(x, y) x\, dx = \mathbb{E}_{X|Y}(x, y). \tag{7.21}$$

故给定 y 时，用后验均值可达到最小值。 □

后文将研究许多带高斯噪声的问题，因此方便起见，将给定问题的 MMSE 估计量定义为最优去噪函数：

$$\eta(R, \Sigma) := \mathbb{E}_P(X \mid X + R + \Sigma Z) = \frac{\int dx\, x e^{-(x-R)^2/(2\Sigma^2)} P(x)}{\int dx\, e^{-(x-R)^2/(2\Sigma^2)} P(x)}. \tag{7.22}$$

译注： 条件期望部分的 $X + R + \Sigma Z$ 按源式照录；右侧积分则对应给定观测值 R 的高斯去噪表达式，两者记法不一致。

有趣的是，采用其他误差时，最优函数可能不同。若用绝对值作为成本，则应改用中位数。

定理 11 (MMAE 估计量)**.** 绝对误差的最优估计量，称为最小平均绝对误差（*MMAE*）估计量，由后验中位数给出：

$$\widehat{x}_{\mathrm{MMAE}}(y) = \mathrm{Median}_{X|Y}(x \mid y). \tag{7.23}$$

证明. 此时有

$$\mathcal{R}^{\mathrm{Posterior}}(y, \widehat{x}(\cdot)) = \int dx^* P_{X|Y}(x^*, y)|\widehat{x}(y) - x^*|, \tag{7.24}$$

$$= \int_{-\infty}^{\widehat{x}} dx^* P_{X|Y}(x^*, y)(-(\widehat{x}(y) - x^*)) + \int_{\widehat{x}}^{\infty} dx^* P_{X|Y}(x^*, y)(\widehat{x}(y) - x^*). \tag{7.25}$$

用 Leibniz 积分法则求导，要求

$$\frac{\partial}{\partial \widehat{x}} \mathcal{R}^{\mathrm{Posterior}}(y, \widehat{x}(\cdot)) = -\int_{-\infty}^{\widehat{x}} dx^* P_{X|Y}(x^*, y) + \int_{\widehat{x}}^{\infty} dx^* P_{X|Y}(x^*, y) = 0, \tag{7.26}$$

这一条件由

$$\widehat{x}_{\mathrm{MMAE}}(y) = \mathrm{Median}_{X|Y}(x \mid y) \tag{7.27}$$

实现。 □

译注： 原文拆分绝对值时两段的符号均与绝对值相反，故相应导数也整体反号；虽然驻点条件仍指向中位数，所写风险本身一般为非正。含点质量时还应使用中位数的不等式 / 次梯度表述，不能默认处处可微或中位数唯一。

最后，若要在有限个假设之间选择，例如 ± 1，或判断 Gauss–Bernoulli 情形的数是否恰为零，一个合适的误差度量是最优决策形式，即最小化犯错次数。

定理 12 (最优决策)**.** 贝叶斯最优决策估计量，对每个类别最大化其（边缘）概率：

$$\widehat{x}_{\mathrm{OBD}}(y) = \operatorname*{argmax}_x P_{X|Y}(x, y). \tag{7.28}$$

7.2.3 回到自由熵

现在讨论如何用统计物理形式体系理解这些问题。后验分布可写为

$$P(x \mid y) = \frac{\exp(\log(P(y \mid x)P(x)))}{P(y)} \equiv P_{\mathrm{Gibbs},y}(x) = \frac{e^{-\mathcal{H}(x;y)}}{Z(y)}. \tag{7.29}$$

一种定义 Boltzmann 测度的方法是取 $\beta = 1$、$\mathcal{H}(x; y) = -\log P(y \mid x) - \log P(x)$ 和 $Z(y) = P(y)$。但实际处理高斯噪声问题时，我们将采用略有不同、更方便的约定：

$$P(x \mid y) = \frac{\exp(\log(P(y \mid x)P(x)))}{P(y)} = \frac{1}{(2\pi\Delta)^{N/2}} \frac{e^{-\sum_i (y_i - x)^2/(2\Delta)} P(x)}{P(y)}, \tag{7.30}$$

$$= \frac{e^{-\sum_i y_i^2/(2\Delta)}}{(2\pi\Delta)^{N/2} P(y)} \left(e^{\sum_i y_i x/\Delta - x^2/(2\Delta)} P(x) \right), \tag{7.31}$$

$$=: \frac{e^{\sum_i (-x^2/(2\Delta) + y_i x/\Delta)} P(x)}{Z(y)}, \tag{7.32}$$

其中

$$Z(y)=\int dx\, e^{\sum_i(-x^2/(2\Delta)+y_i x/\Delta)}P(x)=\left[\frac{e^{-\sum_i y_i^2/(2\Delta)}}{(2\pi\Delta)^{N/2}P(y)}\right]^{-1}.$$

译注：式 (7.31) 原文的 $-x^2/(2\Delta)$ 未置于求和内，而下一式放在求和内；对多次标量测量，这一项应计入 N 次。这里分别保留可见原式。

有趣的是，这一定义下的配分和还等于：y 由含噪信号模型生成的概率，与 y 纯由方差为 Δ 的高斯随机噪声生成的概率之比：

$$Z(y)=\frac{P_Y^{\text{model}}(y)}{P_Y^{\text{random}}(y)}.$$

这在假设检验中称为似然比。如果两个分布相同，则对所有 y 都有 $Z=1$。按照这一定义，与前面一样定义期望自由熵

$$F_N=\mathbb{E}_Y\log Z(y). \tag{7.33}$$

事实上，自由熵恰好是 $P_Y^{\text{model}}(y)$ 与 $P_Y^{\text{random}}(y)$ 之间的 Kullback–Leibler 散度：

$$F_N=\mathbb{E}_Y^{\text{model}}\log\frac{P_Y^{\text{model}}(y)}{P_Y^{\text{random}}(y)}=D_{\mathrm{KL}}(P_Y^{\text{model}}(y)\mid P_Y^{\text{random}}(y)). \tag{7.34}$$

译注：原文紧邻文字先把似然比描述为随机噪声概率与模型概率之比，但公式给出相反次序；译文以可见公式及随后的 KL 表达式为准，明确分子为模型概率。

许多其他信息量也同样值得研究，但它们彼此等价。例如，可使用变量 y 的熵，它与自由熵有简单关系：

$$H(Y)=-\mathbb{E}_Y\log P(y)=N\frac{\mathbb{E}_y[y^2]}{2\Delta}+\frac{N}{2}\log 2\pi\Delta-F_N. \tag{7.35}$$

信息论中更常使用 X 与 Y 的互信息，即它们的联合分布与乘积分布之间的 Kullback–Leibler 散度：

$$I(X,Y)=D_{\mathrm{KL}}(P_{X,Y}\|P_XP_Y). \tag{7.36}$$

同样可将它直接表示为自由熵的函数。利用互信息与条件熵的基本性质（见习题），有

$$I(X,Y)=H(Y)-H(Y\mid X)=H(Y)-\frac{N}{2}\log(2\pi e\Delta), \tag{7.37}$$

$$=-F_N-\frac{N}{2}+N\frac{\mathbb{E}_y[y^2]}{2\Delta}=F-\frac{N}{2}+N\frac{\mathbb{E}_x[x^2]+\Delta}{2\Delta}, \tag{7.38}$$

$$=-F_N+N\frac{\mathbb{E}_x[x^2]}{2\Delta}. \tag{7.39}$$

由于存在这些等价关系，我们将集中研究自由熵。**译注：**式 (7.38) 第二个等号后的 F 为原文写法，与前后的 $-F_N$ 不一致。式 (7.35) 中的 $N\mathbb{E}_y[y^2]$ 采用原文对同类测量分量的简记，不应视作任意向量 Y 的未归一化平方范数。

7.2.4 若干实用恒等式：Nishimori 与 Stein

继续之前，介绍一些后文会频繁使用的重要数学恒等式，特别是在贝叶斯推断中。第一条是高斯积分的一般性质，是分部积分的直接结果，称为 Stein 引理。

引理 7 (Stein 引理)**.** 设 $X \sim \mathcal{N}(\mu, \sigma^2)$。若 g 可微，且 $\mathbb{E}[(X-\mu)g(X)]$ 与 $\mathbb{E}[g'(X)]$ 存在，则

$$\mathbb{E}[g(X)(X-\mu)] = \sigma^2 \mathbb{E}[g'(X)].$$

特别地，当 $X \sim \mathcal{N}(0,1)$ 时，

$$\mathbb{E}[Xg(X)] = \mathbb{E}[g'(X)].$$

证明. 对 g 和 $f = -e^{-x^2/2}/\sqrt{2\pi}$ 应用分部积分公式 $\int f'g = [fg] - \int fg'$ 即得。 □

译注： 分部积分及边界项消失需要相应可积性和边界条件；这里保留作者的简述，不将任意可微性单独作为充分条件。

还有一组极为实用的恒等式，在物理学与纠错编码中通常称为 “Nishimori 对称性”。其一般形式如下。

定理 13 (Nishimori 恒等式)**.** 设 $X^{(1)}, \dots, X^{(k)}$ 为给定 Y 后，从分布 $P(X = \cdot \mid Y)$ 中独立同分布抽取的 k 个样本。以 $\langle \cdot \rangle$ 表示 *“Boltzmann”* 期望，即对后验分布 $P(X = \cdot \mid Y)$ 的平均；以 $\mathbb{E}[\cdot]$ 表示 *“无序”* 期望，即对 (X^*, Y) 的平均。则对任意有界连续函数 f，可把一个副本换成 X^*：

$$\mathbb{E}\left[\left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{(k)})\right\rangle_k\right] = \mathbb{E}\left[\left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{*})\right\rangle_{k-1}\right]. \tag{7.40}$$

证明. 这是 Bayes 定理以及 x^* 与任意副本 $X^{(k)}$ 都服从后验分布的结果。对任意函数 g，更显式地写出 k 个副本上的 Boltzmann 平均：

$$\langle g(X^{(1)}, \dots, X^{(k)})\rangle_k := \int \prod_{i=1}^{k} dx_i P(x_i \mid Y) g(X^{(1)}, \dots, X^{(k)}). \tag{7.41}$$

从式 (7.40) 右端开始，有

$$\begin{aligned}
&\mathbb{E}_{Y, X^*}\left[\left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{*})\right\rangle_{k-1}\right] \\
&= \int dx^* dy\, P(x^* \mid Y) P(Y) \left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{*})\right\rangle_{k-1} \\
&= \mathbb{E}_Y \int dx_k P(x_k \mid y) \left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{k})\right\rangle_{k-1} \\
&= \mathbb{E}_Y\left[\left\langle f(Y, X^{(1)}, \dots, X^{(k-1)}, X^{(k)})\right\rangle_k\right].
\end{aligned}$$

□

以后将省略 Boltzmann 平均的下标 k。Nishimori 性质有许多实用推论。先看 MMSE，它可用重叠量简洁表示：

$$\begin{aligned}
\mathrm{MMSE}(\lambda) &= \mathbb{E}_{y, x^*}[(\langle x\rangle_y - x^*)^2] \\
&= \mathbb{E}_{y, x^*}[\langle x\rangle_y^2 + (x^*)^2 - 2x^*\langle x\rangle_y] = q + q_0 - 2m,
\end{aligned}$$

其中

- $q := \mathbb{E}_y[\langle x\rangle_y^2] = \mathbb{E}_y[\langle x^{(1)}x^{(2)}\rangle_y]$，为两个副本之间的重叠。
- $q_0 := \mathbb{E}_{x^*}[(x^*)^2]$，为自重叠。
- $m := \mathbb{E}_{y,x^*}[x^*\langle x\rangle_y]$，为与真值的重叠。

利用 Nishimori 恒等式，

$$\mathbb{E}_{y,x^*}[\langle f(x,x^*)\rangle_y] = \mathbb{E}_y[\langle f(x^{(1)},x^{(2)})\rangle_y],$$

可得 $q \equiv m$，因此 $\mathrm{MMSE}(\lambda) = q_0 - m$。

7.2.5 I-MMSE 定理

定理 14 (I-MMSE 定理)**.** *对单次测量和高斯噪声，若 $Y = \sqrt{\Delta}Z + X^*$，则互信息或自由熵关于逆噪声的导数给出 MMSE*:

$$\frac{\partial}{\partial \Delta^{-1}} I(\Delta) = \frac{1}{2}\,\mathrm{MMSE}(\lambda) = \frac{1}{2}(q_0 - m), \tag{7.42}$$

$$\frac{\partial}{\partial \Delta^{-1}} F(\Delta) = \frac{1}{2} m. \tag{7.43}$$

证明. 将 F 显式写成高斯噪声的函数：

$$F = \mathbb{E}_{x^*,z} \log \int dx\, P(x) e^{-x^2/(2\Delta) + xx^*/\Delta + zx/\sqrt{\Delta}}. \tag{7.44}$$

求导得

$$\partial_{\Delta^{-1}} F = \mathbb{E}_{x^*,z} \frac{\int dx\, P(x)(-x^2/2 + xx^* + zx\sqrt{\Delta}/2) e^{-x^2/(2\Delta) + xx^*/\Delta + zx/\sqrt{\Delta}}}{\int dx\, P(x) e^{-x^2/(2\Delta) + xx^*/\Delta + zx/\sqrt{\Delta}}}, \tag{7.45}$$

$$= -\frac{1}{2}\mathbb{E}_{z,x^*}[\langle x^2\rangle] + \mathbb{E}_{z,x^*}[\langle x\rangle x^*] + \mathbb{E}_{z,x^*}\left[\frac{\sqrt{\Delta}}{2}\langle x\rangle z\right]. \tag{7.46}$$

对变量 z 使用 Stein 引理，第三项可写为

$$\mathbb{E}_{z,x^*}\left[\frac{\sqrt{\Delta}}{2}\langle x\rangle z\right] = \mathbb{E}_{z,x^*}\left[\frac{\sqrt{\Delta}}{2}\partial_z\langle x\rangle\right] = \frac{1}{2}\mathbb{E}_{z,x^*}[\langle x^2\rangle - \langle x\rangle^2]. \tag{7.47}$$

故

$$\partial_{\Delta^{-1}} F = -\frac{1}{2}\mathbb{E}_{z,x^*}[\langle x^2\rangle] + \mathbb{E}_{z,x^*}[\langle x\rangle x^*] + \frac{1}{2}\mathbb{E}_{z,x^*}[\langle x^2\rangle - \langle x\rangle^2], \tag{7.48}$$

$$= \mathbb{E}_{z,x^*}[\langle x\rangle x^*] - \frac{1}{2}\mathbb{E}_{z,x^*}[\langle x\rangle^2], \tag{7.49}$$

$$= m - \frac{q}{2} = \frac{m}{2}. \tag{7.50}$$

最后一步使用了 Nishimori 恒等式。 □

译注： 本节的贝叶斯匹配设定、噪声独立性及必要的矩条件、求导与积分交换条件须保持；此前定理对有界函数的表述不能单凭文字便直接覆盖所有无界的重叠二阶量。这里忠实保留原推导，不扩展其适用范围。

7.3 应用：稀疏向量去噪

前面讨论的所有定理同样适用于 d 维向量。于是，可以把新得到的知识用于更有意思的问题：稀疏向量去噪。

考虑 d 维向量 x^*。计算机中，d 常为 2 的幂，故取 $d = 2^N$，且只有一个非零分量，恰好等于 1。换言之，x 是 d 个向量 $[10000\ldots]$、$[01000\ldots]$ 等之一。我们没有直接获得该向量，而是得到被很小高斯噪声污染的 d 维向量 y：

$$y = x^* + \sqrt{\frac{\Delta}{N}}\, z. \tag{7.51}$$

能恢复 x^* 吗？按照贝叶斯方法，写出

$$\begin{aligned} P(x \mid y) &= \frac{1}{P(y)} P(x) \prod_i \frac{e^{-(y_i - x_i)^2/(2\Delta/N)}}{\sqrt{2\pi\Delta/N}} \\ &= \frac{\prod_i \mathcal{N}(y_i, 0, \Delta/N)}{P(y)} \prod_i e^{-(x_i^2 - 2x_i y_i)/(2\Delta/N)} P(x). \end{aligned} \tag{7.52}$$

$\prod_i \mathcal{N}(y_i, 0, \Delta/N)$ 正是零模型的概率，即 y 纯为随机向量的情形。此外，先验告诉我们，x 必须是超立方体的某个角点，即除 $x_i = 1$ 外其余分量均为零的向量之一。由此

$$P(x_i \mid y) = \frac{P^{\text{random}}(y)}{P^{\text{model}}(y)} \frac{1}{2^N} e^{N y_i/\Delta - N/(2\Delta)} =: \frac{1}{Z} \frac{1}{2^N} e^{N y_i/\Delta - N/(2\Delta)}. \tag{7.53}$$

与前面一样，配分和是模型概率与零模型概率之比：

$$Z = \frac{1}{2^N} \sum_{i=1}^{d} e^{-N/(2\Delta) + N y_i/\Delta} = \frac{1}{2^N} \sum_{i=1}^{d} e^{-N/(2\Delta) + (N/\Delta)\delta_{i,i^*} + \sqrt{N/\Delta}\, z_i}. \tag{7.54}$$

目标是计算自由熵关于 Δ 的函数：

$$\Phi(\Delta) = \lim_{N\to\infty} \frac{1}{N} \mathbb{E} \log Z. \tag{7.55}$$

应用 I-MMSE 定理，特别得到

$$q := \lim_{N\to\infty} \mathbb{E}\left[\sum_i \frac{\langle x \rangle x^*}{N} \right] = 2\partial_{\Delta^{-1}} \Phi(\Delta). \tag{7.56}$$

译注： 式 (7.53) 的 x_i 在此指第 i 个单点非零的候选向量；原文后续重叠式 (7.56) 又含额外 $1/N$，与单位范数单点向量及 N 缩放后的 I-MMSE 关系需核对。正文原式保留。

如下将看到，这一计算可以严格完成。事实上，可证明自由能具有以下表达式。

定理 15. *定义 $f(\Delta) : \mathbb{R} \to \mathbb{R}$ 为*

$$f(\Delta) = \frac{1}{2\Delta} - \log 2, \qquad \Delta \le \frac{1}{2\log 2}, \tag{7.57}$$

$$f(\Delta) = 0, \qquad \Delta \ge \frac{1}{2\log 2}. \tag{7.58}$$

则自由熵的极限为 $f(\Delta)$。

通过上下界证明这一定理。先看以下引理。

引理 8 (上界)**.**

$$\Phi_N(\Delta) \geq f(\Delta). \tag{7.59}$$

证明. 只保留和式中的一项，即正确位置 i^* 对应的项，得到

$$\Phi_N(\Delta) = \frac{1}{N}\mathbb{E}[\log Z] \geq \frac{1}{N}\mathbb{E}\left[\log\left(\frac{1}{2^N}e^{-N/(2\Delta)+N/\Delta+z\sqrt{N/\Delta}}\right)\right], \tag{7.60}$$

$$\geq \frac{1}{2\Delta} - \log 2. \tag{7.61}$$

另外，无穷噪声下两个分布不可区分，而 Z 是似然比，故 $\Phi_N(\Delta=\infty)=0$。由于

$$\partial_\Delta \Phi_N(\Delta) = (\partial_{\Delta^{-1}}\Phi_N(\Delta))(\partial_\Delta(1/\Delta)) = -\frac{q}{2\Delta^2} \leq 0,$$

所以 $\Phi_N(\Delta)\geq 0$。 □

引理 9 (下界)**.**

$$\Phi_N(\Delta) \leq f(\Delta) + o(1). \tag{7.62}$$

译注：以上两个引理的原文标题分别是 “上界” 和 “下界”，但不等号方向分别给出下界与上界。标题与公式均照录。函数 f 的噪声阈值按本节随后明确写出的 $\Delta_c = 1/(2\log 2)$ 排版；噪声参数本来应取正值，原文函数定义域却写为 $\mathbb{R}$。

证明. 由 Jensen 不等式（退火界）得到：

$$\Phi_N(\Delta) = \frac{1}{N}\mathbb{E}[\log Z]$$
$$\leq \frac{1}{N}\mathbb{E}_{z_{i^*}}\left[\log\left(e^{N/(2\Delta)+z_{i^*}\sqrt{N/\Delta}-N\log 2} + \sum_{i\neq i^*}\mathbb{E}_{z_i}\left[\frac{1}{2^N}e^{-N/(2\Delta)+z_i\sqrt{N/\Delta}}\right]\right)\right].$$

进一步有

$$\Phi_N(\Delta) \leq \frac{1}{N}\mathbb{E}_{z_{i^*}}\left[\log\left(e^{N/(2\Delta)+z_{i^*}\sqrt{N/\Delta}-N\log 2} + \left(1-\frac{1}{2^N}\right)e^{N/(2\Delta)-N/(2\Delta)}\right)\right]$$
$$\leq \frac{1}{N}\mathbb{E}_{z_{i^*}}\left[\log\left(e^{N(1/(2\Delta)-\log 2)+z_{i^*}\sqrt{N/\Delta}}+1\right)\right]. \tag{7.63}$$

直观上，指数中的 $1/(2\Delta)-\log 2$ 为正或负，将分别使该项完全主导表达式，或指数消失。

可严格说明这一点。例如，定义单调递增函数

$$g(z_{i^*}) := e^{N(1/(2\Delta)-\log 2)+z_{i^*}\sqrt{N/\Delta}}+1. \tag{7.64}$$

有 $g(z_{i^*}) \leq g(|z_{i^*}|)$，且

$$\log g(|z_{i^*}|) \leq \log g(0) + |z_{i^*}|\max\frac{g'}{g} = \log g(0) + |z_{i^*}|\sqrt{\frac{N}{\Delta}}. \tag{7.65}$$

因此

$$\frac{1}{N}\mathbb{E}\log g(z_{i^*}) \leq \frac{1}{N}\mathbb{E}\log g(|z_{i^*}|) \leq \frac{1}{N}\log(1+e^{N(1/(2\Delta)-\log 2)}) + \frac{\mathbb{E}|z|}{\sqrt{N\Delta}}, \tag{7.66}$$

$$\leq \frac{1}{N}\log(1+e^{N(1/(2\Delta)-\log 2)}) + o(1). \tag{7.67}$$

注意 $N\to\infty$ 时该界趋于 $f(\Delta)$，将 $1/(2\Delta)-\log 2$ 的指数项提出对数，并使用 $\log(1+x)\leq x$，即可得出结论。 □

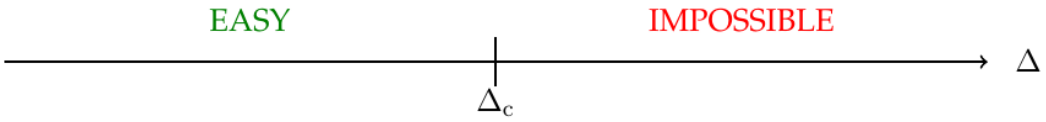
知道自由熵后，就可应用 I-MMSE 定理。根据 Δ 大于还是小于

$$\Delta_c = \frac{1}{2\log 2},$$

会发生相变。

若 $\Delta > \Delta_c$，则 MMSE 为 1，无法找到信号；即使最佳猜测也不优于随机猜测。反之，若 $\Delta < \Delta_c$，则应能解出问题，得到完美的 MMSE，即零误差。

实践中能做到吗？算法是什么？一个熟知的结果是，d 个独立同分布高斯随机变量的最大值渐近为 $\sqrt{2\log d}$，涨落阶为 $1/\sqrt{\log d}$。这里，无信号且方差为 $\sigma^2 = \Delta/N = \Delta\log 2/\log d$ 时，最大值为 $\sqrt{2\Delta\log 2}$，当 $\Delta < \Delta_c$ 时确实小于 1。这意味着，最简单的算法——只保留最大分量——以高概率就是最优的。因此有如下有趣的相图。



图中 EASY 与 IMPOSSIBLE 分别表示容易与不可能区域，横轴为 Δ，分界为 Δ_c。对于维度为 d、噪声方差为 σ^2 的信号，得到 $\sigma_c^2 = 1/(2\log d)$。**译注：**高斯最大值还存在对数修正的确定性中心化；原文关于涨落阶的说法应与该中心化区分。将极限自由熵的导数用于 MMSE 也需要可微点及极限与求导关系，不能直接据此处理临界点。

实际上，在 $\Delta \geq \Delta_c$ 区域还能证明更强的结果。如附录 7.A 所示，不仅自由熵除以 N 趋于零，总自由熵也趋于零。回顾，它正是模型分布与随机分布之间的 KL 散度：

$$F_N = \mathbb{E}_Y^{\text{model}} \log \frac{P_Y^{\text{model}}(y)}{P_Y^{\text{random}}(y)} = D_{\text{KL}}(P_Y^{\text{model}}(y) \mid P_Y^{\text{random}}(y)) \xrightarrow{N\to\infty} 0. \tag{7.68}$$

这意味着两个分布最终趋于相同、不可区分：不仅无法找到信号，甚至在 $\Delta > \Delta_c$ 时无法判断是否藏有信号，因为数据看起来完全像高斯噪声。**译注：**本段起句含等号 $\Delta \geq \Delta_c$，而随后不可区分的陈述及附录证明使用严格条件 $\Delta > \Delta_c$；临界等号情形不能据此视为已证明。

文献说明

关于 Bayes 定理的历史，以及 Laplace 在“逆概率”发明中的基础作用，McGrayne (2011) 有充分讨论。贝叶斯估计是信息论与统计学交叉处的重要领域，可参阅 Cover and Thomas (1991) 等。I-MMSE 定理由 Guo et al. (2005) 提出。Nishimori 对称性由 Nishimori (1980) 引入物理学，很快被发现与信息论（Nishimori, 1993）和贝叶斯推断（Iba, 1999）密切相关。稀疏向量去噪模型见 Donoho et al. (1998)。该问题与 Shannon 随机码（Shannon, 1948）以及统计物理中的随机能量模型（Derrida, 1981）有深刻联系。

7.4 习题

习题 7.1：若干实用的熵恒等式

下文将分布为 $p_X(x)$ 的随机变量 X 的熵记为

$$H(X) = -\int dx\, p(x)\log p(x).$$

- **高斯变量的熵**。证明，从 $\mathcal{N}(m,\Delta)$ 采样的高斯变量的熵为

$$H(X)=\frac{1}{2}\log 2\pi e\Delta.$$

- **互信息**。两个可能相关的变量 X,Y 的互信息，定义为其联合分布与乘积分布之间的 KL 散度，即

$$I(X;Y)=D_{\mathrm{KL}}(P_{X,Y}\|P_XP_Y)=\int dxdy\,p_{X,Y}(x,y)\log\frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)}.$$

  证明互信息满足链式关系

$$I(X;Y)=H(X)-H(X\mid Y)=H(Y)-H(Y\mid X),$$

  其中条件熵 $H(X\mid Y)$ 定义为

$$H(X\mid Y)=-\int dy\,p_Y(y)\int dx\,p_{X|Y}(x\mid y)\log p_{X|Y}(x\mid y).$$

- **高斯变量的条件熵**。给定分布为 $p_X(x)$ 的随机变量 X，以及服从方差为 Δ 的高斯分布的随机变量 Z，定义新变量 $Y=X+Z$。证明条件熵为

$$H(X\mid Y)=\frac{1}{2}\log 2\pi e\Delta.$$

译注：最后一条源文写的是 $H(X\mid Y)$；在独立加性高斯噪声的通常设定下，这一固定表达式对应 $H(Y\mid X)$。原文也未在此条明确写独立性，题目照录并标记，不改成另一道习题。

习题 7.2：数值检验

对前述标量后验一节的三个模型作模拟，使用点估计一节介绍的 MMSE、MAP 与 MMAE 估计量。改变观测数 n（从 10 到 1000，或更多），并对许多实例平均；对每个问题，画出不同风险和不同估计量下，误差随 N 的变化。**译注：**源文指向第 6.2.1、6.2.2 节；本章实际对应第 7.2.1、7.2.2 节，译文以内容定位，保留此处版本编号差异记录。

习题 7.3：二阶导数

前面 I-MMSE 一节已说明：高斯噪声下，自由熵关于 Δ^{-1} 的一阶导数等于重叠 m 的一半。计算二阶导数（再次使用 Stein 与 Nishimori），把它联系到某个量的方差，并证明由此推出自由熵关于 Δ^{-1} 的凸性。**译注：**源文这里引用第 6.2.5 节，本版相应内容位于第 7.2.5 节。

附录 7.A：似然比的更精细计算

这里将证明，当 $\Delta>\Delta_c$ 时，平均配分和不仅趋于零，自由熵的修正实际上还指数小。这需要更精细地分析似然比以及引理 9 中的上界。**译注：**原文此处说“平均配分和趋于零”，而前述讨论的是平均对数配分函数 / 自由熵；作为归一化模型对零模型的似然比，Z 的一般平均性质不能与自由熵混同。保留原文用语并标记。

出发点是式 (7.63)：

$$\Phi_N(\Delta) \le \frac{1}{N}\mathbb{E}_{z_{i^*}}\left[\log\left(e^{N(1/(2\Delta)-\log 2)+z_{i^*}\sqrt{N/\Delta}}+1\right)\right].$$

目标是说明，当 $\Delta > \Delta_c$ 时，它指数小。简化记号，令 $f = -1/(2\Delta) + \log 2 > 0$，将积分分成两部分：

$$\Phi_N(\Delta) \le \frac{1}{N}\mathbb{E}_z[\log(e^{-fN+z\sqrt{N/\Delta}}+1)] = \int_{-\infty}^{+\infty} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-fN+z\sqrt{N/\Delta}}+1), \tag{7.69}$$

$$\le \int_{-\infty}^{\sqrt{N\Delta}f} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-fN+z\sqrt{N/\Delta}}+1) + \int_{\sqrt{N\Delta}f}^{\infty} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-fN+z\sqrt{N/\Delta}}+1), \tag{7.70}$$

$$\le I_1 + I_2. \tag{7.71}$$

先处理 I_1。由于指数项为正，取 z 的 “最坏” 可能值，有

$$\begin{aligned} I_1 &= \int_{-\infty}^{\sqrt{N\Delta}f(1-\epsilon)} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-fN+z\sqrt{N/\Delta}}+1) \\ &\le \int_{-\infty}^{\infty} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-fN+Nf(1-\epsilon)}+1) \\ &\le \int_{-\infty}^{\infty} dz\,\frac{e^{-x^2/2}}{\sqrt{2\pi}}\log(e^{-\epsilon fN}+1) \le e^{-\epsilon fN}, \end{aligned}$$

其中使用了 $\log(1+x) \le x$，故 I_1 的确指数小。

再看 I_2，再次利用 $\log(1+x) \le x$：

$$\begin{aligned} I_2 &= \int_{\sqrt{N\Delta}f(1-\epsilon)}^{\infty} dz\,\frac{e^{-z^2/2}}{\sqrt{2\pi}}\log(e^{-fN+z\sqrt{N/\Delta}}+1) \\ &\le e^{-fN}\int_{\sqrt{N\Delta}f(1-\epsilon)}^{\infty} dz\,\frac{e^{-z^2/2}}{\sqrt{2\pi}}e^{z\sqrt{N/\Delta}}. \end{aligned} \tag{7.72}$$

稍作改写，得

$$\begin{aligned} I_2 &\le e^{-fN+N/(2\Delta)}\int_{\sqrt{N\Delta}f(1-\epsilon)}^{\infty} dz\,\frac{e^{-(z-\sqrt{N/\Delta})^2/2}}{\sqrt{2\pi}} \\ &= e^{-fN+N/(2\Delta)}\int_{\sqrt{N\Delta}f(1-\epsilon)-\sqrt{N/\Delta}}^{\infty} dz\,\frac{e^{-z^2/2}}{\sqrt{2\pi}}, \qquad (7.73) \\ &\le e^{-fN+N/(2\Delta)}\Pr\left(Z > \sqrt{N\Delta}f(1-\epsilon) - \sqrt{\frac{N}{\Delta}}\right). \qquad (7.74) \end{aligned}$$

对高斯随机变量，有 $\Pr(Z > b) \le e^{-b^2/2}$，因此

$$I_2 \le e^{-fN+N/(2\Delta)}e^{-(\sqrt{N\Delta}f(1-\epsilon)-\sqrt{N/\Delta})^2/2}, \tag{7.75}$$

$$= e^{-fN+N/(2\Delta)}e^{-N\Delta f(1-\epsilon)^2/2}e^{-N/(2\Delta)}e^{Nf(1-\epsilon)}, \tag{7.76}$$

$$= e^{-\epsilon N}e^{-N\Delta f(1-\epsilon)^2/2}. \tag{7.77}$$

它也指数衰减，因此得到如下结果。

引理 10 (Kullback–Leibler 散度的指数衰减)**.**

$$NF_n(\Delta) = D_{\mathrm{KL}}(P_Y^{\mathrm{model}}(y) \mid P_Y^{\mathrm{random}}(y)) =\leq Ne^{-KN}, \qquad \Delta > \Delta_c. \tag{7.78}$$

注意，要使散度趋于零，需要总自由熵趋于零，而非仅仅除以 N 后的自由熵密度趋于零。**译注：**本附录按原式保留若干待核问题：式 (7.69) 从期望改为积分时丢失 $1/N$，积分变量为 z 而密度中写 x；两次拆分的阈值分别为 $\sqrt{N\Delta}f$ 与 $\sqrt{N\Delta}f(1-\epsilon)$；高斯尾界 $\Pr(Z>b)\le e^{-b^2/2}$ 需要 $b\ge 0$，此处阈值并非对所有 $\Delta>\Delta_c$ 都非负；式 (7.76) 的平方展开中出现 f 而非 f^2，下一行又漏去 $e^{-\epsilon fN}$ 中的 f。最后一式的 NF_n 与前文总自由熵 F_N 的记法不一致，且源文确印为 $=\leq$。因此，此附录尚不能当作已核实的全参数严格证明，未擅自替换其推导。

附录 7.B：向量去噪的副本计算

用副本法重新计算定理 15 中的自由熵，很有启发性，也是一道很好的练习。计算与后面随机能量模型一章十分相似，建议读者参阅。从这一角度看，当前模型就是随机能量模型的“贝叶斯”版本。

先回顾配分和：

$$Z = \frac{1}{2^N}\sum_{i=1}^{d} e^{-N/(2\Delta)+(N/\Delta)\delta_{i,i^*}+\sqrt{N/\Delta}\,z_i} = e^{-N(\log 2+1/(2\Delta))}\sum_{i=1}^{d} e^{(N/\Delta)\delta_{i,i^*}+\sqrt{N/\Delta}\,z_i}. \tag{7.79}$$

为用副本法计算平均自由熵，从副本配分和开始：

$$Z^n = e^{-nN(\log 2+1/(2\Delta))}\prod_{a=1}^{n}\left(\sum_{i=1}^{d} e^{(N/\Delta)\delta_{i,i^*}+\sqrt{N/\Delta}\,z_i}\right). \tag{7.80}$$

不失一般性取 $i^*=1$，先作看似平凡的改写：

$$\begin{aligned}
Z^n e^{nN(\log 2+1/(2\Delta))} &= \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(\sqrt{N/\Delta}\,z_{i_a}+(N/\Delta)\delta_{i_a,1})}, &(7.81)\\
&= \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}} e^{\sum_{a=1}^{n}\sqrt{N/\Delta}\,z_{i_a}}, &(7.82)\\
&= \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}} e^{\sum_{a=1}^{n}\sum_{j=1}^{d}\sqrt{N/\Delta}\,z_j\delta_{j,i_a}}, &(7.83)\\
&= \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}}\prod_{j=1}^{d} e^{z_j\sum_{a=1}^{n}\sqrt{N/\Delta}\,\delta_{j,i_a}}. &(7.84)
\end{aligned}$$

现在对无序取期望，利用此时出现的是独立高斯变量的乘积：

$$\begin{aligned}
\mathbb{E}[Z^n] &= e^{-nN(\log 2+1/(2\Delta))}\mathbb{E}\left[\sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}}\prod_{j=1}^{d} e^{z_j\sum_{a=1}^{n}\sqrt{N/\Delta}\,\delta_{j,i_a}}\right], &(7.85)\\
&= e^{-nN(\log 2+1/(2\Delta))}\sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}}\prod_{j=1}^{d}\mathbb{E}\left[e^{z_j\sum_{a=1}^{n}\sqrt{N/\Delta}\,\delta_{j,i_a}}\right]. &(7.86)
\end{aligned}$$

对高斯变量使用 $\mathbb{E}[e^{bz}] = e^{b^2/2}$，得到

$$\mathbb{E}[Z^n] = e^{-nN(\log 2 + 1/(2\Delta))} \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}} \prod_{j=1}^{d} e^{(N/(2\Delta))(\sum_{a=1}^{n}\delta_{j,i_a})^2}, \tag{7.87}$$

$$= e^{-nN(\log 2 + 1/(2\Delta))} \sum_{i_1,\dots,i_n=1}^{d} e^{\sum_{a=1}^{n}(N/\Delta)\delta_{i_a,1}} e^{(N/(2\Delta))\sum_{j=1}^{d}\sum_{a,b=1}^{n}\delta_{j,i_a}\delta_{j,i_b}}, \tag{7.88}$$

$$= e^{-nN(\log 2 + 1/(2\Delta))} \sum_{i_1,\dots,i_n=1}^{d} e^{(N/\Delta)(\sum_{a=1}^{n}\delta_{i_a,1} + \frac{1}{2}\sum_{a,b=1}^{n}\delta_{i_a,i_b})}. \tag{7.89}$$

给定副本构型 $(i_1,\dots,i_n)$，各指标取值于 $1,\dots,d$，定义 $n\times n$ 的重叠矩阵 $Q_{ab} = \delta_{i_a,i_b}$。两副本（行与列）的构型不同或相同时，其元素分别为 0 或 1。再定义 $n\times n$ 磁化向量 $M_a = \delta_{i_a,1}$。于是副本和可写为

$$\mathbb{E}[Z^n] = e^{-nN(\log 2 + 1/(2\Delta))} \sum_{i_1,\dots,i_n=1}^{d} e^{(N/\Delta)(\sum_{a=1}^{n} M_a + \frac{1}{2}\sum_{a,b=1}^{n} Q_{a,b})}, \tag{7.90}$$

$$= e^{-nN(\log 2 + 1/(2\Delta))} \sum_{\{Q\},\{M\}} \#(Q,M) e^{(N/\Delta)(\sum_{a=1}^{n} M_a + \frac{1}{2}\sum_{a,b=1}^{n} Q_{a,b})}. \tag{7.91}$$

其中 $\sum_{\{Q\},\{M\}}$ 遍历所有可能的矩阵和向量，$\#(Q,M)$ 是产生重叠矩阵 Q 与磁化向量 M 的构型数。**译注：** 原文将 M_a 称为 $n\times n$ 向量，但其定义只有一个副本指标，维数记法需核对，原文描述照录。

这一形式尚不能直接对 $n\to 0$ 作解析延拓。暂时保持整数 n，自然预期给定重叠矩阵与磁化向量的构型数按指数增长。记 $\#(Q,M) = e^{Ns(Q,M)}$，则

$$e^{nN(\log 2 + 1/(2\Delta))}\mathbb{E}Z^n \approx \int dQ\, dM\, e^{Ns(Q,M) + (N/\Delta)(\sum_{a=1}^{n} M_a + \frac{1}{2}\sum_{a,b=1}^{n} Q_{a,b})}$$
$$=: \int dQ, M\, e^{Ng(\Delta,Q,M)}.$$

由于 N 很大，预期可用 Laplace（或鞍点）近似，选择主导求和的“正确”矩阵 Q 和向量结构。一个自然猜测是副本对称假设：假定所有副本相同，因此系统在副本重标记下不变，即具有置换对称性。

此时 Q, M 的元素只有三种自然选择：

1. 所有副本处于同一个构型，即对所有 a 有 $i_a = i$；再假设 $i \neq 1$。则对所有 a,b 有 $Q_{ab} = 1$，对所有 a 有 $M_a = 0$。这样的构型有 $d-1 \approx 2^N$ 个，故 $s(Q,M) = \log 2$，并得到 $g(\beta, Q) = \log 2 + n^2/\Delta$。它看起来不对：表达式在极限中没有关于 n 的线性部分，故不能将此解用于副本法；显然，这是错误的解析延拓。

2. 所有副本处于同一个“正确”构型 $i_a = i = 1$。则所有 $Q_{ab} = 1$，所有 $M_a = 1$。只有一种可能，故 $s(Q,M) = 0$，$g(\beta, Q) = n/\Delta + n^2/(2\Delta)$。

3. 若所有副本处于不同的随机构型，则 $Q_{aa} = 1$，当 $a \neq b$ 时 $Q_{ab} = 0$，且 $M_a = 0$。此时 $\#(Q) = 2^N(2^N-1)\cdots(2^N - n + 1)$，当 $n \ll N$ 时 $s(Q) \approx n\log 2$。因此 $g(\beta, Q) = n/(2\Delta) + n\log 2$。

在副本对称层次，$n\to 0$ 时的自由熵有两个可能解。第一种情形中，所有副本都处于正确的隐藏解：

$$\mathbb{E}Z^n = e^{-nN(\log 2+1/(2\Delta))+nN/\Delta} = e^{-nN(\log 2-1/(2\Delta))}. \tag{7.92}$$

第二种情形中，所有副本随机分布在所有状态上：

$$\mathbb{E}Z^n = e^{-nN(\log 2+1/(2\Delta))+nN/(2\Delta)+n\log 2} = 0. \tag{7.93}$$

这样便由副本法精确恢复了严格解。选择正确解很容易：自由熵关于 Δ 连续、凸且非负，并随 Δ 增大从无穷趋于零。因此，自由能在 $\Delta<\Delta_c=1/(2\log 2)$ 时必须为 $\log 2-1/(2\Delta)$，在 $\Delta>\Delta_c$ 时为零。**译注：**以上为原文副本启发式论述，保留其结论措辞但不认证解析延拓。第一种构型计数对应的 g 中，按前述指数应核查 $n^2/(2\Delta)$，原文写为 n^2/Δ；“副本相同”也不能与置换对称性无条件等同。式 (7.93) 末项的 $n\log 2$ 缺少 N，且正指数函数被写成等于 0；最后自由能表达式的符号与定理 15 的 $1/(2\Delta)-\log 2$ 相反。前述凸性由 I-MMSE 关于 Δ^{-1} 讨论，此处却称关于 Δ；原文记号 $g(\beta,Q)$ 也未沿用此前的 $g(\Delta,Q,M)$。这些问题均记录，不以副本法段落代替严格结论或擅自修正原式。

8 低秩矩阵分解：尖峰模型

> 信号是真相，噪声则是使我们偏离真相的东西。[……] 区分信号与噪声，既需要科学知识，也需要自知之明：平静地接受无法预测之事，勇敢地预测能够预测之事，并有智慧分清二者。
>
> Nate Silver，《The Signal and the Noise》，2012

介绍贝叶斯估计问题之后，现在将这些技术用于一个非平凡问题。这是检验新知识的理想例子。

8.1 问题设定

尖峰 Wigner 模型

假设给定的数据是按下式生成的 $n\times n$ 对称矩阵 $\mathbf{Y}$：

$$\mathbf{Y}=\sqrt{\frac{\lambda}{N}}\underbrace{\mathbf{x}^*\mathbf{x}^{*\mathsf{T}}}_{N\times N\text{ 秩一矩阵}}+\underbrace{\boldsymbol{\xi}}_{\text{对称、独立同分布噪声}},$$

其中 $\mathbf{x}^*\in\mathbb{R}^N$，$x_i^*\overset{\text{iid}}{\sim}P_X(x)$；当 $i\le j$ 时，$\xi_{ij}=\xi_{ji}\overset{\text{iid}}{\sim}\mathcal{N}(0,1)$。

统计学中称其为 Wigner 尖峰模型。“Wigner”之名来自 $\mathbf{Y}$ 由 Wigner 矩阵（各分量从高斯分布随机抽样的对称随机矩阵）加上一个“尖峰”即秩一矩阵 $\mathbf{x}^*\mathbf{x}^{*\mathsf{T}}$ 构成。任务是由 $\mathbf{Y}$ 恢复向量 $\mathbf{x}$。根据刚学到的知识，可用后验估计实现：

$$P(\mathbf{x}\mid\mathbf{Y})=\frac{1}{Z(\mathbf{Y})}\left[\prod_{i=1}^{N}P_X(x_i)\right]\left[\prod_{i\le j}\frac{e^{-\frac{1}{2}(y_{ij}-\sqrt{\lambda/N}\,x_i^*x_j^*)^2}}{\sqrt{2\pi}}\right].$$

译注：原文矩阵维数先写 $n\times n$ 后用 N；上式后验的似然中仍印真值 $x_i^*x_j^*$，而后续推导改用候选 x_ix_j。两处分别保留，不能把该式按字面当作随 $\mathbf{x}$ 变化的正确似然。对称噪声的独立性指上三角，不是全部矩阵元彼此独立。

尖峰 Wishart 模型（二部向量自旋玻璃模型）

为完整起见，再介绍另一个同样很有意思的模型，称为 Wishart 尖峰模型：

$$\mathbf{Y} = \sqrt{\frac{\lambda}{N}} \underbrace{\mathbf{u}^*\mathbf{v}^{*\mathsf{T}}}_{M\times N \text{ 秩一矩阵}} + \underbrace{\boldsymbol{\xi}}_{\text{独立同分布噪声}},$$

其中 $\mathbf{u}^* \in \mathbb{R}^M$，$u_i^* \overset{\text{iid}}{\sim} P_U(u)$；$\mathbf{v}^* \in \mathbb{R}^N$，$v_i^* \overset{\text{iid}}{\sim} P_V(v)$；$\xi_{ij} \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$。

严格说来，“Wishart” 这一名称可能显得奇怪。它源于：当向量 $\mathbf{u}$ 为高斯时，此模型与另一个涉及 Wishart 矩阵的模型完全相同，后者也称为尖峰协方差模型。事实上，当各因子独立时，可将其视为带加性噪声和标量随机设计的线性模型：

$$\mathbf{y}_i = \sqrt{\frac{\lambda}{N}}\, v_j \mathbf{u} + \boldsymbol{\xi}_j. \tag{8.1}$$

假设 v_j 零均值、单位方差，则这确实是尖峰协方差模型：经验协方差矩阵 $\boldsymbol{\Sigma} = \mathbf{Y}\mathbf{Y}^{\mathsf{T}}/N$ 的均值，是单位矩阵的秩一扰动 $\mathbf{1} + \mathbf{u}\mathbf{u}^{\mathsf{T}}$。随机协方差矩阵称为 Wishart 矩阵，因此这是带秩一扰动的 Wishart 矩阵模型。

无论名称如何，给定矩阵 $\mathbf{Y}$ 后，关于 $\mathbf{X}$ 的后验分布为

$$P(\mathbf{u},\mathbf{v} \mid \mathbf{Y}) = \frac{1}{Z(\mathbf{Y})}\left[\prod_{i=1}^{M} P_U(u_i)\right]\left[\prod_{j=1}^{N} P_V(v_i)\right]\left[\prod_{i,j}\frac{e^{-\frac{1}{2}(y_{ij}-\sqrt{\lambda/N}\,u_i^* v_j^*)^2}}{\sqrt{2\pi}}\right].$$

译注： 以上保留源文的 $\mathbf{y}_i/v_j/\boldsymbol{\xi}_j$、乘积中的 $P_V(v_i)$、后验似然中的真值星号，以及正文的 $\mathbf{X}$ 记法。协方差的秩一项按此前缩放一般还带 λ/N，原文简写未说明吸收该因子；将其认作 Wishart 型协方差时还需明确条件化对象及高斯因子，不能仅凭这一段认作任意先验下完全相同的矩阵系综。

8.2 从后验分布到配分和

现在映射到统计物理表述。对尖峰 Wigner 模型，应用 Bayes 公式：

$$\begin{aligned}
P(\mathbf{x} \mid \mathbf{Y}) &= \frac{P(\mathbf{Y} \mid \mathbf{x})P(\mathbf{x})}{P(\mathbf{Y})} \\
&\propto \left[\prod_i P_X(x_i)\right]\left[\prod_{i\le j}\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(y_{ij}-\sqrt{\lambda/N}\,x_i x_j)^2}\right] \\
&\propto \left[\prod_i P_X(x_i)\right]\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2 x_j^2 + \sqrt{\frac{\lambda}{N}}\,y_{ij}x_i x_j\right]\right\}, \\
\Longrightarrow\quad P(\mathbf{x} \mid \mathbf{Y}) &= \frac{1}{Z(\mathbf{Y})}\left[\prod_i P_X(x_i)\right]\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2 x_j^2 + \sqrt{\frac{\lambda}{N}}\,y_{ij}x_i x_j\right]\right\}, \\
\Longrightarrow\quad \widehat{\mathbf{x}}_{\mathrm{MSE}}(\mathbf{Y}) &= \begin{pmatrix} \widehat{x}_{\mathrm{MSE},1}(\mathbf{Y}) \\ \vdots \\ \widehat{x}_{\mathrm{MSE},N}(\mathbf{Y}) \end{pmatrix}, \\
\widehat{x}_{\mathrm{MSE},i}(\mathbf{Y}) &= \langle x_i \rangle_{\mathbf{Y}} = \int d\mathbf{x}\, P(\mathbf{x} \mid \mathbf{Y}) x_i.
\end{aligned}$$

8.3 副本方法

后验还可写为

$$P(\mathbf{x}\mid\mathbf{Y}) = \frac{1}{Z(\mathbf{Y})}\left[\prod_i P_X(x_i)\right]\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2x_j^2+\sqrt{\frac{\lambda}{N}}\,y_{ij}x_ix_j\right]\right\}$$
$$= \frac{1}{Z(\mathbf{Y})}\left[\prod_i P_X(x_i)\right]\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2x_j^2+\frac{\lambda}{N}x_ix_jx_i^*x_j^*+\sqrt{\frac{\lambda}{N}}\,\xi_{ij}x_ix_j\right]\right\}.$$

所关心的是

$$\lim_{N\to\infty}\mathbb{E}_{\mathbf{Y}}\left[\frac{1}{N}\log Z(\mathbf{Y})\right] = \lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}}\left[\frac{1}{N}\log Z(\mathbf{Y})\right].$$

使用副本法，有

$$\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}}[Z^n] = \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}}\left[\left(\int d\mathbf{x}\left[\prod_i P_X(x_i)\right]\right.\right.$$
$$\left.\left.\times\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2x_j^2+\frac{\lambda}{N}x_ix_jx_i^*x_j^*+\sqrt{\frac{\lambda}{N}}\,\xi_{ij}x_ix_j\right]\right\}\right)^n\right]$$
$$= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}}\left[\prod_{\alpha=1}^n\int d\mathbf{x}^{(\alpha)}\prod_i P_X(x_i^{(\alpha)})\right.$$
$$\left.\times\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}(x_i^{(\alpha)})^2(x_j^{(\alpha)})^2+\frac{\lambda}{N}x_i^{(\alpha)}x_j^{(\alpha)}x_i^*x_j^*+\sqrt{\frac{\lambda}{N}}\,\xi_{ij}x_i^{(\alpha)}x_j^{(\alpha)}\right]\right\}\right]$$
$$= \mathbb{E}_{\mathbf{x}^*}\left[\int\prod_{\alpha,i}P_X(x_i^{(\alpha)})\,dx_i^{(\alpha)}\right.$$
$$\times\exp\left\{\sum_{i\le j}\left[-\frac{\lambda}{2N}\sum_\alpha(x_i^{(\alpha)})^2(x_j^{(\alpha)})^2+\frac{\lambda}{N}\sum_\alpha x_i^{(\alpha)}x_j^{(\alpha)}x_i^*x_j^*\right]\right\}$$
$$\left.\times\underbrace{\prod_{i\le j}\mathbb{E}_{\xi_{ij}}\left[e^{\xi_{ij}\sqrt{\lambda/N}\sum_\alpha x_i^{(\alpha)}x_j^{(\alpha)}}\right]}_{\overset{(a)}{=}\exp\left(\frac{\lambda}{2N}\sum_{i\le j}\sum_{\alpha,\beta}x_i^{(\alpha)}x_j^{(\alpha)}x_i^{(\beta)}x_j^{(\beta)}\right)}\right]$$
$$\overset{(b)}{=}\mathbb{E}_{\mathbf{x}^*}\left[\int\prod_{\alpha,i}P_X(x_i^{(\alpha)})\,dx_i^{(\alpha)}\right.$$
$$\times\exp\left\{-\frac{\lambda N}{4}\sum_\alpha\left(\sum_i\frac{(x_i^{(\alpha)})^2}{N}\right)^2+\frac{\lambda N}{2}\sum_\alpha\left(\sum_i\frac{x_i^*x_i^{(\alpha)}}{N}\right)^2\right.$$
$$\left.\left.+\frac{\lambda N}{4}\sum_{\alpha,\beta}\left(\sum_i\frac{x_i^{(\alpha)}x_i^{(\beta)}}{N}\right)^2\right\}\right]$$
$$= \mathbb{E}_{\mathbf{x}^*}\left[\int\prod_{\alpha,i}P_X(x_i^{(\alpha)})\,dx_i^{(\alpha)}\right.$$
$$\left.\times\exp\left\{\frac{\lambda N}{2}\sum_\alpha\left(\sum_i\frac{x_i^*x_i^{(\alpha)}}{N}\right)^2+\frac{\lambda N}{2}\sum_{\alpha<\beta}\left(\sum_i\frac{x_i^{(\alpha)}x_i^{(\beta)}}{N}\right)^2\right\}\right].$$

按重叠量插入 delta 函数：

$$
\begin{aligned}
\mathbb{E}[Z^n] &\overset{(c)}{=} \mathbb{E}_{\mathbf{x}^*}\Bigg[\int \prod_{\alpha,i} P_X(x_i^{(\alpha)})\,dx_i^{(\alpha)} \int \prod_{\alpha} \delta\left(m_\alpha - \frac{1}{N}\sum_i x_i^{(\alpha)} x_i^*\right) dm_\alpha \\
&\qquad \times \int \prod_{\alpha<\beta} \delta\left(q_{\alpha\beta} - \frac{1}{N}\sum_i x_i^{(\alpha)} x_i^{(\beta)}\right) dq_{\alpha\beta} \exp\left\{\frac{\lambda N}{2}\left[\sum_\alpha m_\alpha^2 + \sum_{\alpha<\beta} q_{\alpha\beta}^2\right]\right\}\Bigg] \\
&\overset{(d)}{=} \mathbb{E}_{\mathbf{x}^*}\Bigg[\int \prod_{\alpha,i} P_X(x_i^{(\alpha)})\,dx_i^{(\alpha)} \int \prod_{\alpha} e^{\widehat{m}_\alpha[N m_\alpha - \sum_i x_i^{(\alpha)} x_i^*]} d\widehat{m}_\alpha dm_\alpha \\
&\qquad \times \int \prod_{\alpha<\beta} e^{\widehat{q}_{\alpha\beta}[N q_{\alpha\beta} - \sum_i x_i^{(\alpha)} x_i^{(\beta)}]} d\widehat{q}_{\alpha\beta} dq_{\alpha\beta} \exp\left\{\frac{\lambda N}{2}\left[\sum_\alpha m_\alpha^2 + \sum_{\alpha<\beta} q_{\alpha\beta}^2\right]\right\}\Bigg] \\
&\overset{(e)}{=} \int \prod_{\alpha} d\widehat{m}_\alpha dm_\alpha \int \prod_{\alpha<\beta} d\widehat{q}_{\alpha\beta} dq_{\alpha\beta} \\
&\qquad \times \exp\left\{\frac{\lambda N}{2}\left[\sum_\alpha m_\alpha^2 + \sum_{\alpha<\beta} q_{\alpha\beta}^2\right] + N\left[\sum_\alpha m_\alpha \widehat{m}_\alpha + \sum_{\alpha<\beta} q_{\alpha\beta}\widehat{q}_{\alpha\beta}\right]\right\} \\
&\qquad \times \left\{\mathbb{E}_{x^*}\left[\int \prod_\alpha P_X(x_\alpha)\,dx_\alpha \exp\left(-\sum_\alpha \widehat{m}_\alpha x^* x_\alpha - \sum_{\alpha<\beta} \widehat{q}_{\alpha\beta} x_\alpha x_\beta\right)\right]\right\}^N .
\end{aligned}
$$

各步含义如下：

(a) 使用 $\int Dz\, e^{az} = e^{a^2/2}$。

(b) 使用

$$\sum_{i\le j} \frac{a_i}{N}\frac{a_j}{N} = \frac{1}{2}\left(\sum_i \frac{a_i}{N}\right)^2 + \frac{1}{2}\sum_i \frac{a_i^2}{N^2},$$

并忽略按 $O(N^{-1})$ 缩放的第二项。

(c) 按与真实信号的重叠 m_α 以及两个不同副本间的重叠 $q_{\alpha\beta}$ 划分这个巨大的积分，定义为

$$m_\alpha = \frac{1}{N}\sum_i x_i^{(\alpha)} x_i^*, \quad \forall \alpha, \qquad\qquad q_{\alpha\beta} = \frac{1}{N}\sum_i x_i^{(\alpha)} x_i^{(\beta)}, \quad \forall \alpha < \beta.$$

(d) 应用 Fourier 变换和变量替换。

(e) 交换积分与期望的次序。由于 x_i^* 独立同分布，对每个 i，元组 $(x_i^*, x_i^{(1)}, \dots, x_i^{(n)})$ 同分布；故改记为 $(x^*, x^{(1)}, \dots, x^{(n)})$，去掉分量指标 i，但保留副本指标 α。

译注：以上将对角修正、Fourier / delta 归一化及其积分路径等写入等号的方式照录原文。忽略对角项需要相应矩控制及主导阶限定；形式 delta 插入与积分交换不自动给出严格有限 N 等式。

副本对称假设

在副本对称假设下，$m_\alpha \equiv m$、$\widehat{m}_\alpha \equiv \widehat{m}$、$q_{\alpha\beta} \equiv q$、$\widehat{q}_{\alpha\beta} \equiv \widehat{q}$。因此

$$
\begin{aligned}
\mathbb{E}[Z^n] &= \int d\widehat{m}\, dm \int d\widehat{q}\, dq\, e^{\frac{\lambda N}{2}[nm^2+(n^2-n)q^2/2]+N[nm\widehat{m}+(n^2-n)q\widehat{q}/2]} \\
&\quad \times \left\{ \mathbb{E}_{x^*}\left[\int \prod_\alpha P_X(x_\alpha)\, dx_\alpha e^{-\widehat{m}\sum_\alpha x^* x_\alpha - \widehat{q}\sum_{\alpha<\beta} x_\alpha x_\beta} \right] \right\}^N \\
&\overset{(a)}{=} \int d\widehat{m}\, dm\, d\widehat{q}\, dq\, e^{nN[\lambda m^2/2+\lambda(n-1)q^2/4+m\widehat{m}+(n-1)q\widehat{q}/2]} \\
&\quad \times \left\{ \mathbb{E}_{x^*}\left[\int \prod_\alpha P_X(x_\alpha)\, dx_\alpha e^{(\widehat{q}/2)\sum_\alpha x_\alpha^2 - \widehat{m}\sum_\alpha x^* x_\alpha} \int Dz\, e^{-iz\sqrt{\widehat{q}}\sum_\alpha x_\alpha} \right] \right\}^N \\
&\overset{(b)}{=} \int d\widehat{m}\, dm\, d\widehat{q}\, dq\, e^{nN[\lambda m^2/2+\lambda(n-1)q^2/4+m\widehat{m}+(n-1)q\widehat{q}/2]} \\
&\quad \times \left\{ \mathbb{E}_{x^*}\left[\int Dz \prod_\alpha \left\{ \int P_X(x_\alpha)\, dx_\alpha\, e^{\widehat{q}x_\alpha^2/2 - \widehat{m}x^* x_\alpha - iz\sqrt{\widehat{q}}x_\alpha} \right\} \right] \right\}^N \\
&\overset{(c)}{=} \int d\widehat{m}\, dm\, d\widehat{q}\, dq\, e^{nN[\lambda m^2/2+\lambda(n-1)q^2/4+m\widehat{m}+(n-1)q\widehat{q}/2]} \\
&\quad \times \left\{ \mathbb{E}_{x^*}\left[\int Dz \left\{ \mathbb{E}_x[e^{\widehat{q}x^2/2 - \widehat{m}x^* x - iz\sqrt{\widehat{q}}x}] \right\}^n \right] \right\}^N \\
&\overset{(d)}{=} \int d\widehat{m}\, dm\, d\widehat{q}\, dq\, e^{nN[\lambda m^2/2-\lambda q^2/4+m\widehat{m}-q\widehat{q}/2]} \\
&\quad \times e^{nN\mathbb{E}_{x^*}\left[\int Dz \log\left(\int P_X(x)\, dx\, e^{\widehat{q}x^2/2 - \widehat{m}x^* x - iz\sqrt{\widehat{q}}x}\right)\right]} \\
&= \int d\widehat{m}\, dm\, d\widehat{q}\, dq\, e^{nN\Phi(m,q,\widehat{m},\widehat{q})},
\end{aligned}
$$

其中

$$
\begin{aligned}
\Phi(m,q,\widehat{m},\widehat{q}) &= \frac{\lambda}{4}(2m^2-q^2) + m\widehat{m} - \frac{1}{2}q\widehat{q} \\
&\quad + \mathbb{E}_{x^*}\left[\int Dz \log\left(\int P_X(x)\, dx\, e^{\widehat{q}x^2/2 + (\sqrt{\widehat{q}}z - \widehat{m}x^*)x} \right) \right].
\end{aligned}
$$

这里各步为

(a) 使用 Hubbard–Stratonovich 变换

$$
\exp\left(-\frac{a}{2}x^2\right) = \frac{1}{\sqrt{2\pi a}} \int_{-\infty}^{\infty} \exp\left(-\frac{z^2}{2a} - ixz\right) dz, \qquad \forall a > 0.
$$

因此

$$
\begin{aligned}
\exp\left(-\widehat{q}\sum_{\alpha<\beta} x_\alpha x_\beta\right) &= \exp\left(-\frac{\widehat{q}}{2}\sum_{\alpha\neq\beta} x_\alpha x_\beta\right) \\
&= \exp\left(\frac{\widehat{q}}{2}\sum_\alpha x_\alpha^2 - \frac{\widehat{q}}{2}\left(\sum_\alpha x_\alpha\right)^2\right) \\
&= \exp\left(\frac{\widehat{q}}{2}\sum_\alpha x_\alpha^2\right) \int \frac{1}{\sqrt{2\pi}} dz\, \exp\left(-\frac{z^2}{2} - iz\sqrt{\widehat{q}}\sum_\alpha x_\alpha\right)
\end{aligned}
$$

$$= \exp\left(\frac{\widehat{q}}{2}\sum_{\alpha} x_\alpha^2\right) \int Dz\, \exp\left(-iz\sqrt{\widehat{q}}\sum_{\alpha} x_\alpha\right).$$

(b) 交换积分次序，并将各 x_α 拆开。

(c) 使用各 x_α 独立同分布这一点。

(d) 取 $n \to 0$，并使用小 n 时的展开

$$\begin{aligned}\mathbb{E}[X^n] = \mathbb{E}[e^{n\log X}] &\simeq \mathbb{E}[1 + n\log X] = 1 + n\mathbb{E}[\log X] \\ &= \exp(\log(1 + n\mathbb{E}[\log X])) \simeq \exp(n\mathbb{E}[\log X]).\end{aligned}$$

根据 Nishimori 恒等式，$q = m$、$\widehat{q} = \widehat{m}$，故简化为

$$\begin{aligned}\Phi_{\text{Nishi}}(m, \widehat{m}) &:= \Phi(m, q, \widehat{m}, \widehat{q})|_{q=m, \widehat{q}=\widehat{m}} \\ &= \frac{\lambda}{4}m^2 + \frac{1}{2}m\widehat{m} + \mathbb{E}_{x^*}\left[\int Dz \log\left(\int P_X(x)\, dx\, e^{\widehat{m}x^2/2 - (i\sqrt{\widehat{m}}z + \widehat{m}x^*)x}\right)\right].\end{aligned}$$

再对 m 求偏导并令其为零：

$$\frac{\partial}{\partial m}\Phi_{\text{Nishi}}(m, \widehat{m}) = \frac{\lambda}{2}m + \frac{1}{2}\widehat{m} = 0 \quad \Longrightarrow \quad \widehat{m} = -\lambda m.$$

代回得到副本对称假设下最终的自由熵函数：

$$\begin{aligned}\Phi_{\text{RS}}(m) &:= \Phi_{\text{Nishi}}(m, \widehat{m})|_{\widehat{m}=-\lambda m} \\ &= -\frac{\lambda}{4}m^2 + \mathbb{E}_{x^*}\left[\int Dz \log\left(\int P_X(x)\, dx\, e^{-\lambda m x^2/2 - (i\sqrt{-\lambda m}z - \lambda m x^*)x}\right)\right] \\ &= -\frac{\lambda}{4}m^2 + \mathbb{E}_{x^*}\left[\int Dz \log\left(\int P_X(x)\, dx\, e^{-\lambda m x^2/2 + (\lambda m x^* - \sqrt{\lambda m}z)x}\right)\right] \\ &= -\frac{\lambda}{4}m^2 + \mathbb{E}_{x^*, z}\left[\log\left(\int P_X(x)\, dx\, e^{-\lambda m x^2/2 + (\lambda m x^* + \sqrt{\lambda m}z)x}\right)\right].\end{aligned}$$

最后一步利用标准高斯分布关于零对称，并作变量替换 $z \leftarrow -z$。因此，m 的自洽方程为

$$m = \mathbb{E}_{x^*, z}\frac{\int dx\, P_X(x) x x^* e^{-\lambda m x^2/2 + (\lambda m x^* - \sqrt{\lambda m}z)x}}{\int dx\, P_X(x) e^{-\lambda m x^2/2 + (\lambda m x^* - \sqrt{\lambda m}z)x}}. \tag{8.2}$$

最多涉及三个积分，因此数值上可以处理。**译注：** 一般 Φ 定义式中的实 $\sqrt{\widehat{q}}z$ 与前面 $-i\sqrt{\widehat{q}}z$ 不一致；从复平方根到实噪声还需指定分支。原文将这些步骤均写为等号，并由 Nishimori 写出共轭变量相等，未在此列出所需鞍点、积分路径、极限交换及解析延拓条件。各式均按源 PDF 保留，不据此认证副本论证严格性。

8.4 通过插值给出严格证明

预备知识

引理 11 (Stein 引理)**.** *设 $X \sim \mathcal{N}(\mu, \sigma^2)$。若 g 可微，且 $\mathbb{E}[(X-\mu)g(X)]$ 和 $\mathbb{E}[g'(X)]$ 存在，则*

$$\mathbb{E}[g(X)(X - \mu)] = \sigma^2\mathbb{E}[g'(X)].$$

特别当 $X \sim \mathcal{N}(0, 1)$ 时，$\mathbb{E}[Xg(X)] = \mathbb{E}[g'(X)]$。

命题 1 (Nishimori 恒等式)**.** 设 (X,Y) 是 *Polish* 空间上的一对随机变量。给定 $k \ge 1$，令 $X^{(1)},\dots,X^{(k)}$ 为给定 Y 后从 $P(X=\cdot \mid Y)$ 独立同分布抽取的 k 个样本，并独立于其他随机变量。以 $\langle\cdot\rangle$ 表示关于 $P(X=\cdot \mid Y)$ 的期望，以 $\mathbb{E}[\cdot]$ 表示关于 (X,Y) 的期望。则对任意有界连续函数 f，

$$\mathbb{E}[\langle f(Y, X^{(1)},\dots,X^{(k-1)}, X^{(k)})\rangle] = \mathbb{E}[\langle f(Y, X^{(1)},\dots,X^{(k-1)}, X)\rangle].$$

推论 1 (两个副本的 Nishimori 恒等式)**.** 考虑模型 $y = g(x^*) + w$，其中 g 是有界连续函数，w 为加性噪声。用 $\langle\cdot\rangle_{x^*,w}$ 表示关于 $P(X=\cdot \mid Y = g(x^*)+w)$ 的期望，则

$$\mathbb{E}_{X^*,W}[\langle f(X, X^*)\rangle_{X^*,W}] = \mathbb{E}_{X^*,W}[\langle f(X^{(1)}, X^{(2)})\rangle_{X^*,W}],$$

其中 $X^{(1)}, X^{(2)}$ 是服从同一后验分布的两个独立副本。

译注：命题中的独立性是在给定观测 Y 后的条件独立性；不能将副本与其共同观测无条件视为独立。Stein 引理的分部积分条件沿用前章说明。

两个问题

问题 A。 上一讲研究了标量去噪问题 $y = \sqrt{\lambda}x^* + \omega$：

$$P(x \mid y) \propto \exp\left(\log P_X(x) - \frac{\lambda}{2}x^2 + \lambda x^* x + \sqrt{\lambda}\,\omega x\right), \tag{8.3}$$

$$\Phi_{\text{denoising}}(\lambda) = \mathbb{E}_{x^*,\omega}\left[\log\left\{\int P_X(x)\,dx\, \exp\left(-\frac{\lambda}{2}x^* + \lambda x^* x + \sqrt{\lambda}\,xz\right)\right\}\right]. \tag{8.4}$$

假设并行求解 N 个这样的问题，观测为 $\mathbf{y} = \sqrt{\lambda m}\,\mathbf{x}^* + \boldsymbol{\omega}$。将其作为问题 A，并定义 Hamiltonian $\mathcal{H}_A(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m)$：

$$P(\mathbf{x} \mid \mathbf{y}) \propto \exp\left\{\sum_i \log P_X(x_i) + \sum_i\left[-\frac{\lambda m}{2}x_i^2 + \lambda m x_i^* x_i + \sqrt{\lambda m}\,\omega_i x_i\right]\right\}, \tag{8.5}$$

$$\mathcal{H}_A(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m) := -\sum_i \log P_X(x_i) - \sum_i\left[-\frac{\lambda m}{2}x_i^2 + \lambda m x_i^* x_i + \sqrt{\lambda m}\,\omega_i x_i\right]. \tag{8.6}$$

其配分函数为

$$\begin{aligned}
&Z_A(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m)\\
&= \int \prod_i dx_i\, \exp\left\{\sum_i\left[\log P_X(x_i) - \frac{\lambda m}{2}x_i^2 + \lambda m x_i^* x_i + \sqrt{\lambda m}\,\omega_i x_i\right]\right\}\\
&= \prod_i \int P_X(x_i)\,dx_i\, \exp\left(-\frac{\lambda m}{2}x_i^2 + \lambda m x_i^* x_i + \sqrt{\lambda m}\,\omega_i x_i\right),
\end{aligned} \tag{8.7}$$

$$\begin{aligned}
&\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m)}{N}\right]\\
&= \frac{1}{N}\sum_i \mathbb{E}_{x_i^*,\omega_i}\left[\log\left\{\int P_X(x_i)\,dx_i\, \exp\left(-\frac{\lambda m}{2}x_i^2 + \lambda m x_i^* x_i + \sqrt{\lambda m}\,\omega_i x_i\right)\right\}\right]\\
&= \mathbb{E}_{x_1^*,\omega_1}\left[\log\left\{\int P_X(x_1)\,dx_1\, \exp\left(-\frac{\lambda m}{2}x_1^2 + \lambda m x_1^* x_1 + \sqrt{\lambda m}\,\omega_1 x_1\right)\right\}\right]\\
&= \Phi_{\text{denoising}}(\lambda m).
\end{aligned} \tag{8.8}$$

译注： 式 (8.4) 中 $-\lambda x^*/2$ 与后续二次项不同，噪声期望取 ω 而被积式写 z，均为原文写法。源物理页 154 的长式越出原画布右缘；上述完整右端及式 (8.7)、(8.8) 的编号，已从同一 PDF 页外既有内容恢复。恢复只扩展派生件画布，未改原内容流；证据路径与哈希见问题记录。

问题 B。 目标是秩一矩阵分解问题 $\mathbf{Y} = \sqrt{\lambda/N}\,\mathbf{x}^*\mathbf{x}^{*\mathsf{T}} + \boldsymbol{\xi}$。定义 Hamiltonian $\mathcal{H}_B$：

$$P(\mathbf{x} \mid \mathbf{Y}) \propto \exp\left\{ \sum_i \log P_X(x_i) + \sum_{i\le j} \left[-\frac{\lambda}{2N} x_i^2 x_j^2 + \frac{\lambda}{N} x_i^* x_j^* x_i x_j + \sqrt{\frac{\lambda}{N}}\,\xi_{ij} x_i x_j \right] \right\}, \tag{8.9}$$

$$\mathcal{H}_B(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\xi}) := -\sum_i \log P_X(x_i) - \sum_{i\le j} \left[-\frac{\lambda}{2N} x_i^2 x_j^2 + \frac{\lambda}{N} x_i^* x_j^* x_i x_j + \sqrt{\frac{\lambda}{N}}\,\xi_{ij} x_i x_j \right]. \tag{8.10}$$

它的配分函数 $Z_B(\lambda, \mathbf{x}^*, \boldsymbol{\xi})$ 正是所关心的量。

由 Guerra 插值得到下界

定义

$$\begin{aligned}
\widetilde{\mathcal{H}}_A^{(t)}(\mathbf{x}\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m) &:= \mathcal{H}_A(\mathbf{x}, t\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m) \\
&= -\sum_i \log P_X(x_i) - \sum_i \left[-\frac{t\lambda m}{2} x_i^2 + t\lambda m x_i^* x_i + \sqrt{t\lambda m}\,\omega_i x_i \right], \\
\widetilde{\mathcal{H}}_B^{(t)}(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\xi}) &:= \mathcal{H}_B(\mathbf{x}, t\lambda, \mathbf{x}^*, \boldsymbol{\xi}) \\
&= -\sum_i \log P_X(x_i) - \sum_{i\le j} \left[-\frac{t\lambda}{2N} x_i^2 x_j^2 + \frac{t\lambda}{N} x_i^* x_j^* x_i x_j + \sqrt{\frac{t\lambda}{N}}\,\xi_{ij} x_i x_j \right].
\end{aligned}$$

插值 Hamiltonian 为

$$\begin{aligned}
\mathcal{H}_t(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m) &:= \widetilde{\mathcal{H}}_A^{(1-t)}(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m) + \widetilde{\mathcal{H}}_B^{(t)}(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\xi}) \\
&= -\sum_i \left[-\frac{(1-t)\lambda m}{2} x_i^2 + (1-t)\lambda m x_i^* x_i + \sqrt{(1-t)\lambda m}\,\omega_i x_i \right] \\
&\quad - \sum_{i\le j} \left[-\frac{t\lambda}{2N} x_i^2 x_j^2 + \frac{t\lambda}{N} x_i^* x_j^* x_i x_j + \sqrt{\frac{t\lambda}{N}}\,\xi_{ij} x_i x_j \right].
\end{aligned} \tag{8.11}$$

相应配分函数记为 $Z_t(\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m)$。**译注：** 源文第一条辅助 Hamiltonian 的自变量写为 $\mathbf{x}\lambda$。插值 Hamiltonian 定义为两条均含完整先验项的 Hamiltonian 之和，但展开式未写先验项；因此先验的计数和积分基准测度在这些表达式之间并不一致。原式及后续端点断言均保留，不静默选择另一插值定义。这是一个具有真值 $\mathbf{x}^*$ 以及如下观测的问题：

$$\begin{cases} Y_{ij} = \sqrt{t\lambda/N}\,x_i^* x_j^* + \xi_{ij}, & 1 \le i \le j \le N, \\ y_i = \sqrt{(1-t)\lambda m}\,x_i^* + \omega_i, & 1 \le i \le N. \end{cases}$$

另外，容易验证

$$\begin{aligned}
\mathcal{H}_0(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m) &\equiv \mathcal{H}_A(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m), \\
Z_0(\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m) &\equiv Z_A(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m), \quad \forall m,
\end{aligned} \tag{8.12}$$

$$\begin{aligned}\mathcal{H}_1(\mathbf{x},\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)&\equiv\mathcal{H}_B(\mathbf{x},\lambda,\mathbf{x}^*,\boldsymbol{\xi}),\\ Z_1(\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)&\equiv Z_B(\lambda,\mathbf{x}^*,\boldsymbol{\xi}),\quad\forall m.\end{aligned}\tag{8.13}$$

注意，

$$\begin{aligned}\partial_t\mathcal{H}_t(\mathbf{x},\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)=&-\sum_i\left[\frac{\lambda m}{2}\sum_i x_i^2-\lambda m x_i^*x_i-\frac{\sqrt{\lambda m}}{2\sqrt{1-t}}\omega_i x_i\right]\\&-\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2x_j^2+\frac{\lambda}{N}x_i^*x_j^*x_ix_j+\frac{\sqrt{\lambda/N}}{2\sqrt{t}}\xi_{ij}x_ix_j\right].\end{aligned}\tag{8.14}$$

因此，该导数可以转化为与 $\mathcal{H}_t$ 关联的若干 Boltzmann 平均项。简记 $\theta=\{\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}\}$。

$$\begin{aligned}\partial_t\frac{\log Z_t(\theta;m)}{N}&=\frac{1}{N}\frac{1}{Z_t(\theta;m)}\partial_t\int d\mathbf{x}\,e^{-\mathcal{H}_t(\mathbf{x},\theta;m)}\\&=-\frac{1}{N}\int d\mathbf{x}\,\underbrace{\frac{e^{-\mathcal{H}_t(\mathbf{x},\theta;m)}}{Z_t(\theta;m)}}_{=P_{t,\theta;m}(\mathbf{x})}\partial_t\mathcal{H}_t(\mathbf{x},\theta;m)=-\frac{1}{N}\left\langle\partial_t\mathcal{H}_t(\mathbf{x},\theta;m)\right\rangle_{t,\theta,m}.\end{aligned}$$

展开为

$$\begin{aligned}\partial_t\frac{\log Z_t(\theta;m)}{N}=-\frac{1}{N}\Bigg\{&\frac{\lambda}{N}\sum_{i\le j}\left[\frac{\left\langle x_i^2x_j^2\right\rangle_{t,\theta,m}}{2}-\left\langle x_i^*x_j^*x_ix_j\right\rangle_{t,\theta,m}\right]\\&-\lambda m\sum_i\left[\frac{\left\langle x_i^2\right\rangle_{t,\theta,m}}{2}-\left\langle x_i^*x_i\right\rangle_{t,\theta,m}\right]\\&-\frac{\sqrt{\lambda/N}}{2\sqrt{t}}\sum_{i\le j}\xi_{ij}\left\langle x_ix_j\right\rangle_{t,\theta,m}+\frac{\sqrt{\lambda m}}{2\sqrt{1-t}}\sum_i\omega_i\left\langle x_i\right\rangle_{t,\theta,m}\Bigg\}.\end{aligned}\tag{8.15}$$

译注： 式 (8.14) 第一项中原文重复 $\sum_i$；式 (8.15) 的整体与各项符号也需和上式逐项核对。原式照录，不通过符号调整改写作者证明。

记信噪比 λ 下秩一矩阵分解（问题 B）的自由熵密度为 $\Phi_{\mathrm{MF}}(\lambda)$。由微积分基本定理，

$$\begin{aligned}\Phi_{\mathrm{MF}}(\lambda)&=\lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}}\left[\frac{\log Z_B(\lambda,\mathbf{x}^*,\boldsymbol{\xi})}{N}\right]\\&=\lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\frac{\log Z_1(\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)}{N}\right]\\&=\lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\frac{\log Z_0(\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)}{N}+\int_0^1 d\tau\,\partial_t\frac{\log Z_t(\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi};m)}{N}\bigg|_{t=\tau}\right]\\&\overset{(a)}{=}\lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right]+\int_0^1 d\tau\,\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\partial_t\frac{\log Z_t(\theta;m)}{N}\bigg|_{t=\tau}\right]\\&\overset{(b)}{=}\lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right]\\&\quad-\frac{\lambda}{N^2}\int_0^1 d\tau\,\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i\le j}\left\{\frac{\left\langle x_i^2x_j^2\right\rangle_{\tau,\theta,m}}{2}-\left\langle x_i^*x_j^*x_ix_j\right\rangle_{\tau,\theta,m}\right\}\right]\\&\quad+\frac{\lambda m}{N}\int_0^1 d\tau\,\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_i\left\{\frac{\left\langle x_i^2\right\rangle_{\tau,\theta,m}}{2}-\left\langle x_i^*x_i\right\rangle_{\tau,\theta,m}\right\}\right]\end{aligned}$$

$$
\begin{aligned}
&\quad + \frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i\le j}\{\langle x_i^2 x_j^2\rangle_{\tau,\theta,m} - \langle x_i x_j\rangle_{\tau,\theta,m}^2\}\right] \\
&\quad - \frac{\lambda m}{2N}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i}\{\langle x_i^2\rangle_{\tau,\theta,m} - \langle x_i\rangle_{\tau,\theta,m}^2\}\right]\Bigg\} \\
&= \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right] \\
&\quad - \frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i\le j}\{\langle x_i x_j\rangle_{\tau,\theta,m}^2 - 2\langle x_i^* x_j^* x_i x_j\rangle_{\tau,\theta,m}\}\right] \\
&\quad + \frac{\lambda m}{2N}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i}\{\langle x_i\rangle_{\tau,\theta,m}^2 - 2\langle x_i^* x_i\rangle_{\tau,\theta,m}\}\right]\Bigg\} \\
&\overset{(c)}{=} \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right] \\
&\quad + \frac{\lambda m}{2N}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i}\{\langle x_i\rangle_{\tau,\theta,m}^2 - 2\langle x_i^* x_i\rangle_{\tau,\theta,m}\}\right] \\
&\quad - \frac{\lambda}{4N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\{\langle x_i x_j\rangle_{\tau,\theta,m}^2 - 2\langle x_i^* x_j^* x_i x_j\rangle_{\tau,\theta,m}\}\right]\Bigg\} \\
&= \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right] \\
&\quad - \frac{\lambda}{4N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\langle x_i x_j\rangle_{\tau,\theta,m}^2 - 2Nm\sum_i \langle x_i\rangle_{\tau,\theta,m}^2\right] \\
&\quad + \frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\langle x_i^* x_j^* x_i x_j\rangle_{\tau,\theta,m}^2 - 2Nm\sum_i \langle x_i^* x_i\rangle_{\tau,\theta,m}^2\right]\Bigg\} \\
&\overset{(d)}{=} \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right] \\
&\quad - \frac{\lambda}{4}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^{(1)}x_i^{(2)} - m\right)^2\right\rangle_{\tau,\theta,m}\right] + \frac{\lambda m^2}{4} \\
&\quad + \frac{\lambda}{2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^* x_i - m\right)^2\right\rangle_{\tau,\theta,m}\right] - \frac{\lambda m^2}{2}\Bigg\} \\
&\overset{(e)}{=} \Phi_{\text{denoising}}(\lambda m) - \frac{\lambda m^2}{4} + \underbrace{\frac{\lambda}{4}\lim_{N\to\infty}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^* x_i - m\right)^2\right\rangle_{\tau,\theta,m}\right]}_{\ge 0}.
\end{aligned}
$$

译注： 步骤 (d)、(e) 和末行非负余项原本位于物理页 156 的画布下缘之外，已从同一 PDF 页外既有内容恢复，未补写作者未写的推导。原布局缺陷仍见原页整页图，恢复证据见问题记录。此前真值重叠平均多出的平方仍按原式保留；恢复末行还保留 τ 下标而未显示积分，此处不静默修正。

其中各步含义如下。

(a) 使用式 (8.12)，以及简记 $\theta=\{\lambda,\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}\}$。

(b) 代入式 (8.15)，并用 Stein 引理处理含 ξ_{ij} 与 ω_i 的项：

$$\begin{aligned}
\partial_{\xi_{ij}}\mathcal{H}_t(\mathbf{x},\theta;m) &= -\sqrt{\frac{t\lambda}{N}}\,x_ix_j,\\
\partial_{\xi_{ij}}Z_t(\theta;m) &= -\int d\mathbf{x}'\,e^{-\mathcal{H}_t(\mathbf{x}',\theta;m)}\partial_{\xi_{ij}}\mathcal{H}_t(\mathbf{x}',\theta;m)\\
&= Z_t(\theta;m)\sqrt{\frac{t\lambda}{N}}\int d\mathbf{x}'\,\frac{e^{-\mathcal{H}_t(\mathbf{x}',\theta;m)}}{Z_t(\theta;m)}x_i'x_j' = Z_t(\theta;m)\sqrt{\frac{t\lambda}{N}}\,\langle x_i'x_j'\rangle_{t,\theta,m},\\
\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\xi_{ij}\langle x_ix_j\rangle_{t,\theta,m}] &= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\partial_{\xi_{ij}}\langle x_ix_j\rangle_{t,\theta,m}]\\
&= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\int d\mathbf{x}\,x_ix_je^{-\mathcal{H}_t(\theta;m)}\left\{\frac{-\partial_{\xi_{ij}}\mathcal{H}_t(\mathbf{x},\theta;m)}{Z_t(\theta;m)}-\frac{\partial_{\xi_{ij}}Z_t(\theta;m)}{[Z_t(\theta;m)]^2}\right\}\right]\\
&= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\int d\mathbf{x}\,x_ix_j\frac{e^{-\mathcal{H}_t(\theta;m)}}{Z_t(\theta;m)}\sqrt{\frac{t\lambda}{N}}\{x_ix_j+\langle x_i'x_j'\rangle_{t,\theta,m}\}\right]\\
&= \sqrt{\frac{t\lambda}{N}}\,\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\langle x_i^2x_j^2\rangle_{t,\theta,m}-\langle x_ix_j\rangle_{t,\theta,m}^2].
\end{aligned}$$

类似地，对含 ω_i 的项，

$$\begin{aligned}
\partial_{\omega_i}\mathcal{H}_t(\mathbf{x},\theta;m) &= -\sqrt{(1-t)\lambda m}\,x_i,\\
\partial_{\omega_i}Z_t(\theta;m) &= -\int d\mathbf{x}'\,e^{-\mathcal{H}_t(\mathbf{x}',\theta;m)}\partial_{\omega_i}\mathcal{H}_t(\mathbf{x}',\theta;m)\\
&= Z_t(\theta;m)\sqrt{(1-t)\lambda m}\int d\mathbf{x}'\,\frac{e^{-\mathcal{H}_t(\mathbf{x}',\theta;m)}}{Z_t(\theta;m)}x_i'x_j'\\
&= Z_t(\theta;m)\sqrt{(1-t)\lambda m}\,\langle x_i'\rangle_{t,\theta,m},\\
\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\omega_i\langle x_i\rangle_{t,\theta,m}] &= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\partial_{\omega_i}\langle x_i\rangle_{t,\theta,m}]\\
&= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\int d\mathbf{x}\,x_ie^{-\mathcal{H}_t(\theta;m)}\left\{\frac{-\partial_{\omega_i}\mathcal{H}_t(\mathbf{x},\theta;m)}{Z_t(\theta;m)}-\frac{\partial_{\omega_i}Z_t(\theta;m)}{[Z_t(\theta;m)]^2}\right\}\right]\\
&= \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\int d\mathbf{x}\,x_i\frac{e^{-\mathcal{H}_t(\theta;m)}}{Z_t(\theta;m)}\sqrt{(1-t)\lambda m}\{x_i+\langle x_i'\rangle_{t,\theta,m}\}\right]\\
&= \sqrt{(1-t)\lambda m}\,\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}[\langle x_i^2\rangle_{t,\theta,m}-\langle x_i\rangle_{t,\theta,m}^2].
\end{aligned}$$

(c) 当各 $a_i=O(1)$ 时，使用

$$\begin{aligned}
\lim_{N\to\infty}\frac{1}{N^2}\sum_{i\le j}a_ia_j &= \lim_{N\to\infty}\frac{1}{2N^2}\left[\sum_{i,j}a_ia_j+\sum_i a_i^2\right]\\
&= \lim_{N\to\infty}\frac{1}{2N^2}\sum_{i,j}a_ia_j+O(N^{-1}) = \lim_{N\to\infty}\frac{1}{2N^2}\sum_{i,j}a_ia_j.
\end{aligned}$$

(d) 将第二项写成不同副本：

$$\frac{\lambda}{4N^2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\langle x_ix_j\rangle_{\tau,\theta,m}^2-2Nm\sum_i\langle x_i\rangle_{\tau,\theta,m}^2\right]$$

$$
\begin{aligned}
&= \frac{\lambda}{4N^2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \sum_{i,j} x_i^{(1)}x_j^{(1)}x_i^{(2)}x_j^{(2)} - 2Nm\sum_i x_i^{(1)}x_i^{(2)}\right\rangle_{\tau,\theta,m}\right] \\
&= \frac{\lambda}{4N^2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\sum_i x_i^{(1)}x_i^{(2)}\right)^2 - 2Nm\left(\sum_i x_i^{(1)}x_i^{(2)}\right) + N^2m^2\right\rangle_{\tau,\theta,m} - N^2m^2\right] \\
&= \frac{\lambda}{4}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\frac{1}{N}\sum_i x_i^{(1)}x_i^{(2)} - m\right)^2\right\rangle_{\tau,\theta,m}\right] - \frac{\lambda m^2}{4}.
\end{aligned}
$$

类似地，

$$
\begin{aligned}
&\frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\left\langle x_i^*x_j^*x_ix_j\right\rangle_{\tau,\theta,m}^2 - 2Nm\sum_i\left\langle x_i^*x_i\right\rangle_{\tau,\theta,m}^2\right] \\
&\quad= \frac{\lambda}{2N^2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \sum_{i,j} x_i^*x_j^*x_ix_j - 2Nm\sum_i x_i^*x_i\right\rangle_{\tau,\theta,m}\right] \\
&\quad= \frac{\lambda}{2N^2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\sum_i x_i^*x_i\right)^2 - 2Nm\left(\sum_i x_i^*x_i\right) + N^2m^2\right\rangle_{\tau,\theta,\xi} - N^2m^2\right] \\
&\quad= \frac{\lambda}{2}\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\sum_i x_i^*x_i - m\right)^2\right\rangle_{\tau,\theta,m}\right] - \frac{\lambda m^2}{2}.
\end{aligned}
$$

(e) 使用式 (8.8) 以及 Nishimori 恒等式，使得

$$
\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\sum_i x_i^*x_i - m\right)^2\right\rangle_{\tau,\theta,m}\right] = \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle \left(\sum_i x_i^{(1)}x_i^{(2)} - m\right)^2\right\rangle_{\tau,\theta,m}\right].
$$

于是得到下界

$$
\begin{aligned}
&\Phi_{\mathrm{MF}}(\lambda) \geq \Phi_{\mathrm{denoising}}(\lambda m) - \frac{\lambda m^2}{4}, \quad \forall m, \\
\Longrightarrow \quad &\Phi_{\mathrm{MF}}(\lambda) = \max_m\left[\Phi_{\mathrm{denoising}}(\lambda m) - \frac{\lambda m^2}{4}\right].
\end{aligned}
$$

译注： 源 PDF 的这些步骤还有可见不一致：Stein 中间式的花括号为加号而最后给出减号；ω_i 的配分函数导数多出 x_j'；完成平方的后一组式子丢失积分及重叠的 $1/N$，下标由 m 改为 ξ，且平方的位置变化。最后从单侧下界直接写出等号，仍需下文另一侧上界。这里保留各中间式和源编号引用，不修补为另一份证明。

由固定磁化模型得到上界

首先重新定义问题 A 的 Hamiltonian，将部分 m 换成 θ：

$$
\widehat{\mathcal{H}}_A(\mathbf{x},\lambda,\mathbf{x}^*,\boldsymbol{\omega};m,q) := -\sum_i \log P_X(x_i) - \sum_i\left[-\frac{\lambda q}{2}x_i^2 + \lambda m x^*x + \sqrt{\lambda q}\,\omega_i x_i\right]. \tag{8.16}
$$

如前，定义插值 Hamiltonian：

$$
\widetilde{\widehat{\mathcal{H}}}_A^{(t)} := \widehat{\mathcal{H}}_A(\mathbf{x},t\lambda,\mathbf{x}^*,\boldsymbol{\omega};m,q)
$$

$$= -\sum_i \log P_X(x_i) - \sum_i \left[-\frac{t\lambda q}{2} x_i^2 + t\lambda m x^* x + \sqrt{t\lambda q}\, \omega_i x_i \right].$$

$$\begin{aligned} \widehat{\mathcal{H}}_t(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m, q) &:= \widetilde{\widehat{\mathcal{H}}}_A^{(1-t)}(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m) + \widetilde{\mathcal{H}}_B^{(t)}(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\xi}) \\ &= -\sum_i \left[-\frac{(1-t)\lambda q}{2} x_i^2 + (1-t)\lambda m x_i^* x_i + \sqrt{(1-t)\lambda q}\, \omega_i x_i \right] \\ &\quad - \sum_{i \le j} \left[-\frac{t\lambda}{2N} x_i^2 x_j^2 + \frac{t\lambda}{N} x_i^* x_j^* x_i x_j + \sqrt{\frac{t\lambda}{N}}\, \xi_{ij} x_i x_j \right]. \end{aligned} \tag{8.17}$$

考虑固定磁化值 $M = N^{-1}\sum_i x_i^* x_i$ 的模型：使用上述同一族 Hamiltonian，但系统只包含具有给定磁化 M 的构型。

$$Z_A^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m, q, M) := \int d\mathbf{x}\, e^{-\widehat{\mathcal{H}}_A(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}; m, q)} \delta\left(M - \frac{1}{N}\sum_i x_i^* x_i \right), \tag{8.18}$$

$$Z_B^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\xi}; M) := \int d\mathbf{x}\, e^{-\mathcal{H}_B(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\xi})} \delta\left(M - \frac{1}{N}\sum_i x_i^* x_i \right), \tag{8.19}$$

$$Z_t^{\text{fixed}}(\theta; m, q, M) := \int d\mathbf{x}\, e^{-\widehat{\mathcal{H}}_t(\mathbf{x}, \theta; m, q)} \delta\left(M - \frac{1}{N}\sum_i x_i^* x_i \right). \tag{8.20}$$

容易验证，对所有 m, q，有 $Z_1^{\text{fixed}}(\theta; m, q, M) \equiv Z_B^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\xi}; M)$。再次考虑所关心的量

$$\Phi_{\text{MF}}^{\text{fixed}}(\lambda; M) := \lim_{N\to\infty} \mathbb{E}_{\mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}} \left[\frac{\log Z_B^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\xi}; M)}{N} \right].$$

注意，

$$\begin{aligned} \partial_t \widehat{\mathcal{H}}_t(\mathbf{x}, \lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m, q) &= -\sum_i \left[\frac{\lambda q}{2} \sum_i x_i^2 - \lambda m x_i^* x_i - \frac{\sqrt{\lambda q}}{2\sqrt{1-t}} \omega_i x_i \right] \\ &\quad - \sum_{i \le j} \left[-\frac{\lambda}{2N} x_i^2 x_j^2 + \frac{\lambda}{N} x_i^* x_j^* x_i x_j + \frac{\sqrt{\lambda/N}}{2\sqrt{t}} \xi_{ij} x_i x_j \right]. \end{aligned} \tag{8.21}$$

该导数可转化为固定磁化 M 时、与 $\widehat{\mathcal{H}}_t$ 关联的若干 Boltzmann 平均项，仍简记 $\theta = \{\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}\}$。

$$\begin{aligned} &\partial_t \frac{\log Z_t^{\text{fixed}}(\theta; m, q, M)}{N} \\ &= \frac{1}{N} \frac{1}{Z_t^{\text{fixed}}(\theta; m, q, M)} \partial_t \int d\mathbf{x}\, e^{-\widehat{\mathcal{H}}_t(\mathbf{x}, \theta; m, q)} \delta\left(M - \frac{1}{N}\sum_i x_i^* x_i \right) \\ &= -\frac{1}{N} \int d\mathbf{x} \underbrace{\frac{e^{-\widehat{\mathcal{H}}_t(\mathbf{x}, \theta; m, q)} \delta(M - N^{-1}\sum_i x_i^* x_i)}{Z_t(\theta; m)}}_{= P_{t, \theta, m, q, M}(\mathbf{x})} \partial_t \widehat{\mathcal{H}}_t(\mathbf{x}, \theta; m, q) \\ &= -\frac{1}{N} \left\langle \partial_t \widehat{\mathcal{H}}_t(\mathbf{x}, \theta; m, q) \right\rangle_{t, \theta, m, q, M}. \end{aligned}$$

于是

$$
\begin{aligned}
&\partial_t \frac{\log Z_t^{\text{fixed}}(\theta; m, q, M)}{N} \\
&= -\frac{1}{N}\Bigg\{ \frac{\lambda}{N} \sum_{i \le j} \left[\frac{\left\langle x_i^2 x_j^2 \right\rangle_{t,\theta,m,q,M}}{2} - \left\langle x_i^* x_j^* x_i x_j \right\rangle_{t,\theta,m,q,M} \right] \\
&\quad - \lambda \sum_i \left[\frac{q}{2} \left\langle x_i^2 \right\rangle_{t,\theta,m,q,M} - m \left\langle x_i^* x_i \right\rangle_{t,\theta,m,q,M} \right] - \frac{\sqrt{\lambda/N}}{2\sqrt{t}} \sum_{i \le j} \xi_{ij} \left\langle x_i x_j \right\rangle_{t,\theta,m,q,M} \\
&\quad + \frac{\sqrt{\lambda q}}{2\sqrt{1-t}} \sum_i \omega_i \left\langle x_i \right\rangle_{t,\theta,m,q,M} \Bigg\}.
\end{aligned}
\tag{8.22}
$$

译注： 开头文字说将 m 换为 θ，实际公式使用 q；另有 x^*x 未带分量指标、辅助 Hamiltonian 自变量缺 q、导数重复求和等原记法。固定磁化的概率密度分母仍写成不带 fixed 的 $Z_t(\theta; m)$，与前一行定义不符；均按可见源式保留。

用上述同样的方法重新计算，得到

$$
\begin{aligned}
&\Phi_{\text{MF}}^{\text{fixed}}(\lambda; M) \\
&= \lim_{N\to\infty} \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\xi}} \left[\frac{\log Z_B^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\xi}; M)}{N} \right] \\
&= \lim_{N\to\infty} \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\frac{\log Z_1^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m, q, M)}{N} \right] \\
&= \lim_{N\to\infty} \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \Bigg[\frac{\log Z_0^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m, q, M)}{N} \\
&\qquad + \int_0^1 d\tau \, \partial_t \frac{\log Z_t^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}, \boldsymbol{\xi}; m, q, M)}{N} \Big|_{t=\tau} \Bigg] \\
&= \lim_{N\to\infty} \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}} \left[\frac{\log Z_A^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m, q, M)}{N} \right] + \int_0^1 d\tau \, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\partial_t \frac{\log Z_t^{\text{fixed}}(\theta; m, q, M)}{N} \Big|_{t=\tau} \right] \\
&= \lim_{N\to\infty} \Bigg\{ \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}} \left[\frac{\log Z_A^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m, q, M)}{N} \right] \\
&\qquad - \frac{\lambda}{N^2} \int_0^1 d\tau \, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\sum_{i \le j} \left\{ \frac{\left\langle x_i^2 x_j^2 \right\rangle_{\tau,\theta,m,q,M}}{2} - \left\langle x_i^* x_j^* x_i x_j \right\rangle_{\tau,\theta,m,q,M} \right\} \right] \\
&\qquad + \frac{\lambda}{N} \int_0^1 d\tau \, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\sum_i \left\{ \frac{q}{2} \left\langle x_i^2 \right\rangle_{\tau,\theta,m,q,M} - m \left\langle x_i^* x_i \right\rangle_{\tau,\theta,m,q,M} \right\} \right] \\
&\qquad + \frac{\lambda}{2N^2} \int_0^1 d\tau \, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\sum_{i \le j} \{ \left\langle x_i^2 x_j^2 \right\rangle_{\tau,\theta,m,q,M} - \left\langle x_i x_j \right\rangle_{\tau,\theta,m,q,M}^2 \} \right] \\
&\qquad - \frac{\lambda q}{2N} \int_0^1 d\tau \, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}} \left[\sum_i \{ \left\langle x_i^2 \right\rangle_{\tau,\theta,m,q,M} - \left\langle x_i \right\rangle_{\tau,\theta,m,q,M}^2 \} \right] \Bigg\} \\
&= \lim_{N\to\infty} \Bigg\{ \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}} \left[\frac{\log Z_A^{\text{fixed}}(\lambda, \mathbf{x}^*, \boldsymbol{\omega}; m, q, M)}{N} \right]
\end{aligned}
$$

$$
\begin{aligned}
&\quad - \frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i\le j}\{\langle x_i x_j\rangle^2_{\tau,\theta,m,q,M} - 2\left\langle x_i^* x_j^* x_i x_j\right\rangle_{\tau,\theta,m,q,M}\}\right] \\
&\quad + \frac{\lambda}{2N}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_i\{q\langle x_i\rangle^2_{\tau,\theta,m,q,M} - 2m\langle x_i^* x_i\rangle_{\tau,\theta,m,q,M}\}\right]\Bigg\} \\
&= \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A^{\text{fixed}}(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m,q,M)}{N}\right] \\
&\quad - \frac{\lambda}{4N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\{\langle x_i x_j\rangle^2_{\tau,\theta,m,q,M} - 2\left\langle x_i^* x_j^* x_i x_j\right\rangle_{\tau,\theta,m,q,M}\}\right] \\
&\quad + \frac{\lambda}{2N}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_i\{q\langle x_i\rangle^2_{\tau,\theta,m,q,M} - 2m\langle x_i^* x_i\rangle_{\tau,\theta,m,q,M}\}\right]\Bigg\} \\
&= \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A^{\text{fixed}}(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m,q,M)}{N}\right] \\
&\quad - \frac{\lambda}{4N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\langle x_i x_j\rangle^2_{\tau,\theta,m,q,M} - 2Nq\sum_i\langle x_i\rangle^2_{\tau,\theta,m,q,M}\right] \\
&\quad + \frac{\lambda}{2N^2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\sum_{i,j}\left\langle x_i^* x_j^* x_i x_j\right\rangle^2_{\tau,\theta,m,q,M} - 2Nm\sum_i\langle x_i^* x_i\rangle^2_{\tau,\theta,m,q,M}\right]\Bigg\} \\
&\le \lim_{N\to\infty}\Bigg\{\mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega}}\left[\frac{\log Z_A(\lambda,\mathbf{x}^*,\boldsymbol{\omega};m)}{N}\right] \\
&\quad - \frac{\lambda}{4}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^{(1)}x_i^{(2)} - q\right)^2\right\rangle_{\tau,\theta,m,q,M}\right] + \frac{\lambda q^2}{4} \\
&\quad + \frac{\lambda}{2}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^* x_i - m\right)^2\right\rangle_{\tau,\theta,m,q,M}\right] - \frac{\lambda m^2}{2}\Bigg\} \\
&= \Phi_{\text{denoising}}(\lambda m) + \frac{\lambda q^2}{4} + \frac{\lambda}{2}(M-m)^2 - \frac{\lambda m^2}{2} \\
&\quad \underbrace{- \frac{\lambda}{4}\lim_{N\to\infty}\int_0^1 d\tau\, \mathbb{E}_{\mathbf{x}^*,\boldsymbol{\omega},\boldsymbol{\xi}}\left[\left\langle\left(\frac{1}{N}\sum_i x_i^{(1)}x_i^{(2)} - q\right)^2\right\rangle_{\tau,\theta,m,q,M}\right]}_{\ge 0}.
\end{aligned}
$$

译注： 末尾不等式、完成平方表达式和非负余项已从同一 PDF 物理页 161 的页外既有内容恢复；不是跨版补充或译者补证。真值重叠的平方位置及去掉 fixed 后的 Z_A 等记法沿用原式，仍需另行数学核查。

于是得到上界

$$
\begin{aligned}
&\Phi_{\text{MF}}^{\text{Fixed}}(\lambda;M) \le \Phi_{\text{denoising}}(\lambda m) + \frac{\lambda q^2}{4} + \frac{\lambda}{2}(M-m)^2 - \frac{\lambda m^2}{2}, \quad \forall m,q, \\
\Longrightarrow \quad &\Phi_{\text{MF}}^{\text{fixed}}(\lambda;M) \le \min_{m,q}\left[\Phi_{\text{denoising}}(\lambda m) + \frac{\lambda q^2}{4} + \frac{\lambda}{2}(M-m)^2 - \frac{\lambda m^2}{2}\right].
\end{aligned}
$$

夹逼 $\Phi_{\mathrm{MF}}(\lambda)$

大 N 极限中，Boltzmann 分布由具有特定磁化的构型主导。因此，利用 Laplace 方法（这里的处理略为粗略），有

$$\begin{aligned}\Phi_{\mathrm{MF}}(\lambda) &= \max_{M} \Phi_{\mathrm{MF}}^{\mathrm{fixed}}(\lambda, M) \\ &\le \max_{M} \min_{m,q} \left[\Phi_{\mathrm{denoising}}(\lambda m) + \frac{\lambda q^2}{4} + \frac{\lambda}{2}(M-m)^2 - \frac{\lambda m^2}{2} \right] \\ &\le \max_{M} \left[\Phi_{\mathrm{denoising}}(\lambda m) + \frac{\lambda q^2}{4} + \frac{\lambda}{2}(M-m)^2 - \frac{\lambda m^2}{2} \right]_{m=M, q=M} \\ &= \max_{M} \left[\Phi_{\mathrm{denoising}}(\lambda M) - \frac{\lambda M^2}{4} \right].\end{aligned}$$

最后，结合两侧界，并注意 $\Phi_{\mathrm{MF}}(\lambda)$ 不依赖于 m, M，

$$\begin{cases} \Phi_{\mathrm{MF}}(\lambda) \ge \max_m [\Phi_{\mathrm{denoising}}(\lambda m) - \lambda m^2/4], \\ \Phi_{\mathrm{MF}}(\lambda) \le \max_M [\Phi_{\mathrm{denoising}}(\lambda M) - \lambda M^2/4], \end{cases}$$

于是

$$\Phi_{\mathrm{MF}}(\lambda) = \max_{m} \left[\Phi_{\mathrm{denoising}}(\lambda m) - \frac{\lambda m^2}{4} \right].$$

译注：本节标题中的“严格证明”及以上结论为原文措辞。固定磁化的 delta、连续 / 离散先验、允许的 m, q, M 范围、矩条件及极限和极值交换没有在本节完整列出；加之已定位的先验计数、原布局越界和符号问题，本轮仅完成忠实翻译，不宣称这份源文推导本身已通过严格性审查。

文献说明

Nishimori (1980) 说明了其对称性对副本对称性的含义。关于扰动的现代方法，见 Korada and Macris (2009)、Abbe and Montanari (2013)、Coja-Oghlan et al. (2018)。尖峰 Wigner 模型近几十年得到了深入研究，并成为许多基础论文的主题，例如 Johnstone (2001)、Baik et al. (2005)。Lesieur et al. (2017) 详细综述了副本方法。结果首次由 Barbier et al. (2016) 证明；本节介绍的是 El Alaoui and Krzakala (2018) 后来给出的另一证明。借助普遍性定理（Krzakala et al., 2016），许多问题可归结为这类低秩分解问题的变体，相应一般公式已由 Lelarge and Miolane (2019)、Miolane (2017)、Barbier and Macris (2019) 证明。还可推广到几乎任意先验，包括神经网络生成模型（Aubin et al., 2020）。

8.5 习题

习题 8.1：BBP 转变

考虑秩一分解模型，向量 $\mathbf{x}$ 的各分量从 $\mathcal{N}(0,1)$ 均匀采样。

1. 使用副本自由熵表达式，证明后验估计 $\langle X \rangle$ 与真值 x^* 之间的重叠 m 满足自洽方程。

2. 数值求解该方程，并说明只有当信噪比 $\lambda > 1$ 时 m 才非零。

3. 随后，生成矩阵

$$\mathbf{Y} = \sqrt{\frac{\lambda}{N}} \underbrace{\mathbf{x}^*\mathbf{x}^{*\mathsf{T}}}_{N\times N \text{ 秩一矩阵}} + \underbrace{\boldsymbol{\xi}}_{\text{对称、独立同分布噪声}},$$

作模型模拟。将这一方法得到的 MMSE 与自己设计的任意求解算法进行比较。例如，一个经典算法是把 $\mathbf{Y}$ 最大本征值对应的本征向量用作估计量。

译注：原文将“从高斯分布采样”修饰为“均匀”；向量在符号翻转对称先验下还有整体正负号不可辨识性，直接后验均值可为零。习题中非零重叠、符号选择 / 微扰以及本征向量归一化的条件未在此说明，不能静默补作既有假设。

习题 8.2：更多相变

考虑秩一分解模型，各分量分别采用如下分布。

模型 1： 从 ± 1 均匀采样。

模型 2： 以概率 ρ 从 ± 1 均匀采样；否则以概率 $1-\rho$ 取零。

1. 使用副本自由熵表达式，证明后验均值估计 $\langle X\rangle$ 与真值 X^* 之间的重叠 m 满足自洽方程。
2. 数值求解该方程，说明模型 1 只有在信噪比 $\lambda > 1$ 时重叠非零，模型 2 则有非平凡临界值。还需检验：当 ρ 足够小时，模型 2 的转变为一阶。

9 空腔法与近似消息传递

9.1 自洽方程

对 N 个变量，

$$-\mathcal{H}_N = \sum_{1\le i\le j}\left[-\frac{x_i^2x_j^2\lambda}{2N} + \frac{x_ix_jx_i^*x_j^*\lambda}{N} + x_ix_j\xi_{ij}\sqrt{\frac{\lambda}{N}}\right]. \tag{9.1}$$

对 $N+1$ 个变量，

$$-\mathcal{H}_{N+1} = \sum_{0\le i\le j}\left[-\frac{x_i^2x_j^2\lambda}{2(N+1)} + \frac{x_ix_jx_i^*x_j^*\lambda}{N+1} + x_ix_j\xi_{ij}\sqrt{\frac{\lambda}{N+1}}\right], \tag{9.2}$$

$$= \sum_{1\le i\le j}\left[-\frac{x_i^2x_j^2\lambda}{2(N+1)} + \frac{x_ix_jx_i^*x_j^*\lambda}{N+1} + x_ix_j\xi_{ij}\sqrt{\frac{\lambda}{N+1}}\right] - \frac{x_0^2\lambda}{2}\sum_i\frac{x_i^2}{N+1} + x_0x_0^*\lambda\sum_i\frac{x_ix_i^*}{N+1} + x_0\sum_i x_i\xi_{0i}\sqrt{\frac{\lambda}{N+1}}, \tag{9.3}$$

$$= -\mathcal{H}_N\left(\lambda\frac{N}{N+1}\right) - \frac{x_0^2\lambda}{2}\sum_i\frac{x_i^2}{N} + x_0x_0^*\sum_i\frac{x_ix_i^*}{N} + x_0\sum_i x_i\xi_{0i}\sqrt{\frac{\lambda}{N}} + o(1). \tag{9.4}$$

现在考察新自旋的平均磁化，必须满足

$$m=\mathbb{E}_{\xi,x^*,x_0^*,\xi_0}\frac{\int dx_0\,P_X(x_0)x_0x_0^*\left\langle e^{-\frac{x_0^2\lambda}{2}\sum_i x_i^2/N+x_0x_0^*\sum_i x_0x_0^*/N+x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N}{\int dx_0\,P_X(x_0)\left\langle e^{-\frac{x_0^2\lambda}{2}\sum_i x_i^2/N+x_0x_0^*\sum_i x_ix_i^*/N+x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N}. \tag{9.5}$$

为计算括号中的项，利用重叠的测度集中，得到

$$\left\langle e^{-\frac{x_0^2\lambda}{2}\sum_i x_i^2/N+x_0x_0^*\sum_i x_ix_i^*/N+x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N \approx \left\langle e^{-x_0^2\lambda\rho/2+x_0x_0^*m+x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N, \tag{9.6}$$

$$= e^{-x_0^2\lambda\rho/2+x_0x_0^*m}\left\langle e^{x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N. \tag{9.7}$$

如何处理最后一项？可以按 m 的幂展开！集中性提示 x_i 与 x_j 仅弱相关，因此希望有

$$\begin{aligned}
\left\langle e^{x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N &= \left\langle \prod_i e^{x_0x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N \\
&\approx \left\langle \prod_i\left(1+x_0x_i\xi_{0i}\sqrt{\frac{\lambda}{N}}+\frac{(x_0x_i)^2}{2}\xi_{0i}^2\frac{\lambda}{N}\right)\right\rangle_N \\
&\approx \prod_i\left(1+x_0\langle x_i\rangle\xi_{0i}\sqrt{\frac{\lambda}{N}}+\frac{1}{2}x_0^2\langle x_i^2\rangle\xi_{0i}^2\frac{\lambda}{N}\right) \\
&\approx \prod_i\left(1+x_0\langle x_i\rangle\xi_{0i}\sqrt{\frac{\lambda}{N}}+\frac{1}{2}x_0^2\langle x_i^2\rangle\frac{\lambda}{N}\right) \\
&\approx e^{x_0\sum_i\langle x_i\rangle\xi_{0i}\sqrt{\lambda/N}-\frac{x_0^2}{2}\sum_i\langle x_i\rangle^2\xi_{0i}^2\lambda/N+\frac{x_0^2}{2}\sum_i\langle x_i^2\rangle\xi_{0i}^2\lambda/N} \\
&\approx e^{x_0\sum_i\langle x_i\rangle\xi_{0i}\sqrt{\lambda/N}-x_0^2q\lambda/2+x_0^2\rho\lambda/2}.
\end{aligned} \tag{9.8}$$

这一点实际上可以严格证明。考虑两个表达式

$$A=-\frac{x_0^2}{2}\lambda\rho+x_0\sum_i\xi_{i0}x_i\sqrt{\frac{\lambda}{N}}, \tag{9.9}$$

$$B=-\frac{x_0^2}{2}\lambda q+x_0\sum_i\xi_{i0}\langle x_i\rangle\sqrt{\frac{\lambda}{N}}. \tag{9.10}$$

用高斯积分及集中性可检验

$$\mathbb{E}\langle(e^A-e^B)^2\rangle\to 0. \tag{9.11}$$

于是得到

$$\begin{aligned}
&\left\langle e^{-\frac{x_0^2\lambda}{2}\sum_i x_i^2/N+x_0x_0^*\sum_i x_0x_0^*/N+x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N \\
&\quad\approx e^{-x_0^2\lambda q/2+x_0x_0^*m+x_0\sum_i\langle x_i\rangle\xi_{0i}\sqrt{\lambda/N}}.
\end{aligned} \tag{9.12}$$

由中心极限定理，最后一项是随机高斯变量，因此

$$m=\mathbb{E}_{x_0^*,z}\frac{\int dx_0\,P_X(x_0)x_0^*x_0e^{-x_0^2q\lambda/2+x_0x_0^*m+x_0\sqrt{\lambda q}z}}{\int dx_0\,P_X(x_0)e^{-x_0^2q\lambda/2+x_0x_0^*m+x_0\sqrt{\lambda q}z}}. \tag{9.13}$$

这样便从严格计算恢复了自洽方程，这正是空腔法的力量！**译注：**本节保留源式可见差异：新自旋展开后真值耦合项的 λ 消失；式 (9.5) 分子及式 (9.12) 的求和又写成 $x_0x_0^*$ 而非 $x_ix_i^*$。从弱相关、集中性到指数函数的均方接近和 CLT 需要矩控制及相应条件，源文此处未给完整证明，不把作者“严格”措辞升级为本轮认证。

9.2 用空腔法处理秩一问题

还可以导出自由能。为此需要跟踪所有 $O(1)$ 常数项，写成

$$-\mathcal{H}_{N+1} = \sum_{0\le i\le j}\left[-\frac{x_i^2x_j^2\lambda}{2(N+1)} + \frac{x_ix_jx_i^*x_j^*\lambda}{N+1} + x_ix_j\xi_{ij}\sqrt{\frac{\lambda}{N+1}}\right], \tag{9.14}$$

$$= \sum_{1\le i\le j}\left[-\frac{x_i^2x_j^2\lambda}{2(N+1)} + \frac{x_ix_jx_i^*x_j^*\lambda}{N+1} + x_ix_j\xi_{ij}\sqrt{\frac{\lambda}{N+1}}\right] - \frac{x_0^2\lambda}{2}\sum_i\frac{x_i^2}{N+1} + x_0x_0^*\lambda\sum_i\frac{x_ix_i^*}{N+1} + x_0\sum_i x_i\xi_{0i}\sqrt{\frac{\lambda}{N+1}}. \tag{9.15}$$

对第一组括号按 N 展开，只保留 $O(1)$ 项，可识别出

$$(\cdot) = -\mathcal{H}_N + \frac{\lambda}{2}\sum_{i\le j}\frac{x_i^2x_j^2}{N^2} - \lambda\sum_{i\le j}\frac{x_ix_i^*x_jx_j^*}{N^2} - \frac{1}{2N}\sqrt{\frac{\lambda}{N}}\sum_{i\le j}x_ix_i\xi_{ij} + o(1), \tag{9.16}$$

$$= -\mathcal{H}_N + \frac{\lambda}{4}\sum_{i,j}\frac{x_i^2x_j^2}{N^2} - \frac{\lambda}{2}\sum_{i,j}\frac{x_ix_i^*x_jx_j^*}{N^2} - \frac{1}{4N}\sqrt{\frac{\lambda}{N}}\sum_{i,j}x_ix_i\xi_{ij} + o(1), \tag{9.17}$$

$$= -\mathcal{H}_N + \frac{\lambda}{4}\left(\sum_i\frac{x_i^2}{N}\right)^2 - \frac{\lambda}{2}\left(\sum_i\frac{x_ix_i^*}{N}\right)^2 - \frac{1}{4N}\sqrt{\frac{\lambda}{N}}\sum_{i,j}x_ix_i\xi_{ij} + o(1). \tag{9.18}$$

于是

$$-\mathcal{H}_{N+1} = -\mathcal{H}_N + \frac{\lambda}{4}\left(\sum_i\frac{x_i^2}{N}\right)^2 - \frac{\lambda}{2}\left(\sum_i\frac{x_ix_i^*}{N}\right)^2 - \frac{1}{4N}\sqrt{\frac{\lambda}{N}}\sum_{i,j}x_ix_i\xi_{ij} + o(1) - \frac{x_0^2\lambda}{2}\sum_i\frac{x_i^2}{N} + x_0x_0^*\sum_i\frac{x_ix_i^*}{N} + x_0\sum_i x_i\xi_{0i}\sqrt{\frac{\lambda}{N}}.$$

现在用空腔法计算自由能：

$$\begin{aligned} F &\approx \mathbb{E}\log\frac{Z_{N+1}}{Z_N} \\ &= \mathbb{E}_{\xi,x^*}\log\left\langle e^{\frac{\lambda}{4}(\sum_i x_i^2/N)^2 - \frac{\lambda}{2}(\sum_i x_ix_i^*/N)^2 + \frac{1}{4N}\sqrt{\lambda/N}\sum_{i,j}x_ix_i\xi_{ij}}\right\rangle_N \\ &\quad + \mathbb{E}_{\xi,x^*,\xi_0}\log\int dx_0\,P(x_0)\left\langle e^{-\frac{x_0^2\lambda}{2}\sum_i x_i^2/N + x_0x_0^*\sum_i x_ix_i^*/N + x_0\sum_i x_i\xi_{0i}\sqrt{\lambda/N}}\right\rangle_N. \end{aligned} \tag{9.19}$$

除了高斯随机变量 ξ_{ij},ξ_{0i} 外，各项看起来都较简单，并依赖于序参量。事实上，第二行已处理过，故可进一步简化为

$$\begin{aligned} F &\approx \mathbb{E}\log\frac{Z_{N+1}}{Z_N} \\ &= \mathbb{E}_{\xi,x^*}\log\left\langle e^{\frac{\lambda}{4}(\sum_i x_i^2/N)^2 - \frac{\lambda}{2}(\sum_i x_ix_i^*/N)^2 + \frac{1}{4N}\sqrt{\lambda/N}\sum_{i,j}x_ix_i\xi_{ij}}\right\rangle_N \\ &\quad + \mathbb{E}_{\xi,x^*,\xi_0}\log\int dx_0\,P_X(x_0)e^{-x_0^2\lambda q/2 + x_0x_0^*m + x_0\sum_i\langle x_i\rangle\xi_{0i}\sqrt{\lambda/N}}. \end{aligned} \tag{9.20}$$

处理第一行。首先由集中性，

$$\sum_i\frac{x_ix_i^*}{N}\to m, \qquad \sum_i\frac{x_i^2}{N}\to\rho. \tag{9.21}$$

因此可写为

$$\left\langle e^{\frac{\lambda}{4}(\sum_i x_i^2/N)^2-\frac{\lambda}{2}(\sum_i x_i x_i^*/N)^2+\frac{1}{4N}\sqrt{\lambda/N}\sum_{i,j}x_i x_j\xi_{ij}}\right\rangle$$

$$= o(1) + \left\langle e^{\rho^2\lambda/4-m\lambda/2+(1/(4N))\sqrt{\lambda/N}\,x_i x_i\xi_{ij}}\right\rangle, \tag{9.22}$$

$$= o(1) + e^{\rho^2\lambda/4-m\lambda/2}\left\langle \prod_{ij} e^{(1/(4N))\sqrt{\lambda/N}\,x_i x_j\xi_{ij}}\right\rangle. \tag{9.23}$$

最后一项看起来复杂，但同样满足集中性。先利用 Stein 引理：

$$\mathbb{E}\left\langle \frac{1}{4N}\sqrt{\frac{\lambda}{N}}\sum_{i,j}x_i x_j\xi_{ij}\right\rangle = \mathbb{E}\left\langle \sum\left(\frac{\lambda}{4N^2}\langle x_i^2x_j^2\rangle - \langle x_i x_j\rangle^2\right)\right\rangle. \tag{9.24}$$

还可计算该量的方差，检验其集中性。这实际上就是矩阵 MMSE。因此

$$\left\langle e^{\frac{\lambda}{4}(\sum_i x_i^2/N)^2-\frac{\lambda}{2}(\sum_i x_i x_i^*/N)^2+\frac{1}{4N}\sqrt{\lambda/N}\sum_{i,j}x_i x_j\xi_{ij}}\right\rangle \tag{9.25}$$

$$\approx e^{\lambda\rho^2/4-\lambda m/2+\frac{\lambda}{4N^2}\sum_{ij}\langle x_i^2x_j^2\rangle-\langle x_i x_j\rangle^2}, \tag{9.26}$$

$$\approx e^{\lambda q/4-\lambda m/2}. \tag{9.27}$$

再用 Nishimori 恒等式 $m=q$，得到

$$F \approx -\frac{\lambda m}{4} + \mathbb{E}_{x^*,z}\log\int dx_0\, P_X(x_0)e^{-x_0^2\lambda m/2+x_0x_0^*m+x_0x_0^*\sqrt{\lambda m}z}. \tag{9.28}$$

译注：以上保留源文的 x_ix_i 与 x_ix_j 混用、噪声修正正负号改变、真值重叠从 m^2 变为 m、式 (9.22) 右端缺少求和、式 (9.24) 系数括号不一致，式 (9.26) 的减项 $-\langle x_ix_j\rangle^2$ 之前未印把该减项纳入求和与系数的括号（这里保留源字面，作用域及作者意图未确认），以及末式额外的 x_0^* 噪声因子。该自由熵末式与前章的 $-\lambda m^2/4$ 及标量去噪指数不同，不能静默合并为已验证的同一表达式。

9.3 AMP

回到空腔方程，新自旋 x_0“看到” 的有效模型为

$$x_0 \sim \frac{1}{Z}P_X(x_0)e^{-\frac{x_0^2\lambda}{2}\sum_i\langle x_i\rangle^2/N+x_0x_0^*(\lambda/N)\sum_i\langle x_i\rangle x_i^*/N+x_0\sum_i\langle x_i\rangle\xi_{0i}\sqrt{\lambda/N}}. \tag{9.29}$$

能将其转化为算法吗？回顾 $y_{ij}=x_i^*x_j^*\sqrt{\lambda/n}+\xi_{ij}$，可写为

$$x_0 \sim \frac{1}{Z}P_X(x_0)e^{-\frac{x_0^2\lambda}{2}\sum_i\langle x_i\rangle^2/N+\sqrt{\lambda/N}\,x_0\sum_i y_{0i}\langle x_i\rangle}. \tag{9.30}$$

定义去噪函数 $\eta(A,B)$：

$$\eta(A,B) := \frac{\int dx_0\, P_X(x_0)x_0e^{-x_0^2A/2+x_0B}}{\int dx\, P_X(x_0)e^{-x_0^2A/2+x_0B}}. \tag{9.31}$$

x_0 的均值和二阶矩可表示为

$$\langle x_0\rangle = \eta\left(\lambda\sum_i\langle x_i\rangle_c^2/N, \sqrt{\frac{\lambda}{N}}\sum_i\langle x_i\rangle_c y_{0i}\right), \tag{9.32}$$

$$\langle x_0^2\rangle - \langle x_0\rangle^2 = \eta'\left(\sum_i \langle x_i\rangle_c^2/N, \sqrt{\frac{\lambda}{N}}\sum_i \langle x_i\rangle_c y_{0i}\right), \tag{9.33}$$

其中 η' 为关于 B 的导数。

很容易想把它改成迭代算法。以 $\widehat{x}$ 表示时刻 t 对 x 边缘分布的估计，写成

$$\mathbf{h}^t = \sqrt{\frac{\lambda}{N}}\,\widehat{\mathbf{x}}^t\mathbf{Y}, \tag{9.34}$$

$$\widehat{\mathbf{x}}^{t+1} = \eta\left(\lambda\frac{\widehat{\mathbf{x}}^t\cdot\widehat{\mathbf{x}}^{t+1}}{N}, \mathbf{h}^t\right). \tag{9.35}$$

但有一个问题：我们得到的确实是 X_0 的均值，它却不是作为 x_i 实际均值的函数，而是作为没有 X_0 的系统中的 x_i 均值的函数；该系统就是移除 x_0 后的空腔系统。所需的是把 X_0 的均值表示为 x_i 实际均值的函数，而非空腔均值的函数！

Thouless、Anderson 和 Palmer 用 Onsager 回缩项解决了这一问题。一阶近似下，可以将缺少 x_0 时的 x_i 空腔均值表示为存在 x_0 时的实际均值的函数：

$$\begin{aligned}
\langle x_i\rangle_c &\approx \eta\left(\lambda\sum_{j\neq 0}\langle x_j\rangle_c^2/N, \sqrt{\frac{\lambda}{N}}\sum_{j\neq 0}\langle x_j\rangle_c y_{ij}\right)\\
&\approx \eta\left(\lambda\sum_{j\neq 0}\langle x_j\rangle^2/N, \sqrt{\frac{\lambda}{N}}\sum_{j\neq 0}\langle x_j\rangle y_{ij}\right), &(9.36)\\
&\approx \eta\left(\lambda\sum_{j}\langle x_j\rangle^2/N - \lambda\langle x_0\rangle^2/N, \sqrt{\frac{\lambda}{N}}\sum_{j}\langle x_j\rangle y_{ij} - \sqrt{\frac{\lambda}{N}}\langle x_0\rangle y_{i0}\right), &(9.37)\\
&\approx \eta\left(\lambda\sum_{j}\langle x_j\rangle^2/N, \sqrt{\frac{\lambda}{N}}\sum_{j}\langle x_j\rangle y_{ij}\right) - (\partial_B\eta)\sqrt{\frac{\lambda}{N}}\langle x_0\rangle y_{i0} + O(1/N), &(9.38)\\
&\approx \langle x_i\rangle - \eta'\sqrt{\frac{\lambda}{N}}\langle x_0\rangle y_{i0} + O(1/N). &(9.39)
\end{aligned}$$

因此算法需作小幅修正。作用于自旋 0 的局域场现在为

$$\sqrt{\frac{\lambda}{N}}\sum_i y_{0i}\langle x_i\rangle_c \longrightarrow \sqrt{\frac{\lambda}{N}}\sum_i y_{0i}\left(\langle x_i\rangle - \eta_i'\sqrt{\frac{\lambda}{N}}\langle x_0\rangle y_{i0}\right).$$

即

$$\begin{aligned}
&\sqrt{\frac{\lambda}{N}}\sum_i y_{0i}\langle x_i\rangle - \lambda\left(\frac{1}{N}\sum_i \eta_i' y_{01}^2\right)\langle x_0\rangle, &(9.40)\\
&\approx \sqrt{\frac{\lambda}{N}}\sum_i y_{0i}\langle x_i\rangle - \lambda\left(\frac{1}{N}\sum_i \eta_i'\right)\langle x_0\rangle. &(9.41)
\end{aligned}$$

于是，迭代算法可写成

$$\mathbf{h}^t = \sqrt{\frac{\lambda}{N}}\,\widehat{\mathbf{x}}^t\mathbf{Y} - \lambda\left(\frac{1}{N}\sum_i \eta_i'\right)\widehat{\mathbf{x}}^{t-1}, \tag{9.42}$$

$$\widehat{\mathbf{x}}^{t+1} = \eta\left(\lambda\frac{\widehat{\mathbf{x}}^t\cdot\widehat{\mathbf{x}}^t}{N}, \mathbf{h}^t\right). \tag{9.43}$$

这一算法通常称为近似消息传递，简称 AMP。对 z 的修正称为 Onsager 反作用项。

算法特别有力之处在于，z 在每一步都是真正的空腔场，而我们知道空腔场的分布！由式 (9.30) 和 (9.13)，预期 h 服从高斯分布：

$$\mathbf{h}^t = \lambda m^t \mathbf{x}^* + \sqrt{\lambda m^t}\,\mathbf{z}, \tag{9.44}$$

其中

$$m^{t+1} = \mathbb{E}_{x_0^*,z} \frac{\int dx_0\, P_X(x_0) x_0^* x_0 e^{-x_0^2 m^t \lambda/2 + \lambda x_0 x_0^* m^t - x_0\sqrt{\lambda m^t} z}}{\int dx_0\, P_X(x_0) e^{-x_0^2 m^t \lambda/2 + \lambda x_0 x_0^* m^t - x_0\sqrt{\lambda m^t} z}}. \tag{9.45}$$

换言之，可以逐步跟踪算法的表现。最后这个方程通常称为算法的 “状态演化”。

这些结果实际上可严格化（Bolthausen、Bayati–Montanari、Fletcher–Rangan）。

定理 16 (AMP 与状态演化，非正式表述)**.** *给定式 (9.42) 的 AMP 算法，当 $n \to \infty$ 时，以高概率，算法的行为如同 $\mathbf{h}^t = \mathbf{x}^* m^t + \sqrt{\lambda q^t}\,\mathbf{z}$，其中 m^t 由式 (9.13) 给出。*

译注：以下均按原文保留：式 (9.29) 真值项的额外 $1/N$；n/N 混用；去噪器分母的 dx/x_0；方差式首参数缺 λ；朴素迭代右端出现未来的 $\widehat{x}^{t+1}$；Onsager 求和写 y_{01}^2 而非 y_{0i}^2；文中把 $\mathbf{h}$ 场又称为 z，且定理中信号系数缺少上一式的 λ。Onsager 导数的时间指标和初始化、先验矩条件以及状态演化的精确概率意义未在非正式定理中完整列明，不能把有限维等式、经验分布极限和逐坐标分布混同。

9.4 习题

习题 9.1：AMP

对前面章节习题中讨论的问题实现 AMP，并将其表现与最优表现比较。**译注：**源文指第 7 章习题；本版秩一分解的对应习题在第 8 节，前版章号残留待与两个版本逐项对照。本题不在翻译范围内另行补写实现或解答。

文献说明

本节介绍的空腔法由 Parisi、Mézard 与 Virasoro 发展，见 Mézard et al. (1987a,b)。自 Aizenman et al. (2003) 开创相关方向以来，它也常用于数学物理；Lelarge and Miolane (2019) 将其用于本章问题。将空腔法视为算法的观点最初来自 Thouless、Anderson 与 Palmer，见 Thouless et al. (1977)，该论文对统计物理界有深远影响。对其迭代算法形式及严格状态演化的研究，见 Bolthausen (2014)、Bayati and Montanari (2011)。对于当前低秩问题，最初由 Rangan and Fletcher (2012) 研究，随后 Lesieur et al. (2017) 从信念传播出发推导并详细讨论。

10 随机块模型与社区发现

10.1 模型定义

本讲讨论稀疏网络的聚类，也称社区发现问题。为建立具体图景，可以想象 Facebook 网络中一所高中学生对应的部分：互为朋友的用户之间有边。已知连接图，希望从网络恢复与高中班

级对应的学生划分。信号来自这样的想法：同班学生比不同班学生更可能成为朋友，因此也更可能相连。描述这种情形的一个广泛研究的简单模型，称为随机块模型，下面将介绍并研究它。

N 个节点 $i = 1, \dots, N$ 各属于 q 个类别 / 群组之一。表示节点 i 所属群组的变量记为 $s_i^* \in \{1, 2, \dots, q\}$。节点以概率 $n_a \geq 0$ 属于群组 a；这是预期群组大小所占比例，满足 $\sum_{a=1}^{q} n_a = 1$。

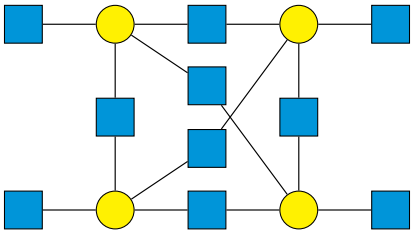
图的边按如下方式生成：对每对节点 i, j，独立决定边 (ij) 是否存在，概率为

$$\begin{cases} P((ij) \in E, A_{ij} = 1 \mid s_i^*, s_j^*) = p_{s_i^* s_j^*}, \\ P((ij) \notin E, A_{ij} = 0 \mid s_i^*, s_j^*) = 1 - p_{s_i^* s_j^*}, \end{cases} \quad \Longrightarrow \quad G(V, E) \text{ 与 } A_{ij},$$

其中 p_{ab} 是对称的 $q \times q$ 矩阵。

社区发现的目标是：给定邻接矩阵 A_{ij}，找到 $\widehat{s}_i$，使其在某种自然距离下尽量接近 s_i^*，例如尽量减少分错群组的节点数。下文既讨论算法已知模型参数 $\theta = (n_a, p_{ab}, q)$ 的情形，也讨论参数未知、需要学习的情形。按照上一讲的推断思路，自然采用贝叶斯推断：参数 θ 已知时，连接图中关于 s_i^* 可提取的全部信息，都包含在后验分布中：

$$\begin{aligned} P(\{s_i\}_{i=1}^N \mid G, \theta) &= \frac{1}{Z_G} P(G \mid \{s_i\}_{i=1}^N, \theta) P(\{s_i\}_{i=1}^N \mid \theta) \\ &= \frac{1}{Z_G} \prod_{i<j} \left[(1 - p_{s_i, s_j})^{1 - A_{ij}} p_{s_i, s_j}^{A_{ij}} \right] \prod_{i=1}^{N} n_{s_i}. \end{aligned}$$



这对应完全连接的图模型：每个变量有一个因子节点，每对无序变量也各有一个因子节点。

我们将研究这一后验，考察哪种算法表现最好，它是否达到信息论最优表现，以及问题中是否存在有趣的相变。为得到自平均结果，研究热力学极限 $N \to \infty$，并取 $p_{ab} = c_{ab}/N$，其中 $c_{ab}, n_a, q = O(1)$。其直觉是：图的大小增大时，每个节点仍平均具有 $O(1)$ 个邻居，就像现实中每个人的平均朋友数并不随世界大小改变。这一极限也很有挑战性，呈现出有趣行为。

群组 a 中节点（即 $s_i^* = a$）的平均度为

$$c_a = \sum_{b=1}^{q} p_{ab} N n_b = \sum_{b=1}^{q} \frac{c_{ab}}{N} N n_b \qquad \sum_{b=1}^{q} c_{ab} n_b. \tag{10.1}$$

译注： 源式 (10.1) 的第二、第三求和间未印等号，本译保留空隙；按 $p_{ab} = c_{ab}/N$，两者代数相等，仅为译者解释，源意图未确认。源中 N 的约分划线在此略去。可见它不依赖于 N：节点数增加时，平均度保持不变。总体平均度为

$$c = \sum_{a,b} c_{ab} n_a n_b. \tag{10.2}$$

译注： 边的独立性是在给定全部群组标签后而言；有限 N 时应区分节点自身与其他同组节点，以上平均度沿用原文的主导阶表达式。

10.2 贝叶斯推断与参数学习

先定义自然的表现度量：原赋值 $\{s_i^*\}$ 与估计 $\{t_i\}$ 之间的一致度：

$$A(\{s_i^*\},\{t_i\}) = \max_{\pi} \frac{1}{N}\sum_{i} \delta_{s_i^*,\pi(t_i)}, \tag{10.3}$$

其中 π 遍历 q 个元素的所有置换。再定义归一化一致度，称为重叠：

$$Q(\{s_i^*\},\{t_i\}) = \max_{\pi} \frac{N^{-1}\sum_i \delta_{s_i^*,\pi(t_i)} - \max_a n_a}{1-\max_a n_a}. \tag{10.4}$$

按此定义，若所有 $s_i^* = t_i$，即无误差地找回原标签，则 $Q=1$。反之，若只知道群组大小 n_a，并为最大化每个节点分配正确的概率而将所有节点分到最大群组，则 $Q=0$。若在 $N\to\infty$ 热力学极限中，重叠严格为正并由某个正常数从下方界定，就称估计标签 $\{t_i\}$ 与原标签 $\{s_i^*\}$ 相关。

10.2.1 已知参数的社区发现

给定参数 $\theta=\{q,\{n_a\},\{c_{ab}\}\}$，随机块模型同时生成邻接矩阵为 A 的图 G 与给定群组赋值 $\{s_i\}$ 的概率为

$$P(G,\{s_i\}\mid\theta) = \prod_{i<j}\left[\left(\frac{c_{s_i,s_j}}{N}\right)^{A_{ij}}\left(1-\frac{c_{s_i,s_j}}{N}\right)^{1-A_{ij}}\right]\prod_i n_{s_i}. \tag{10.5}$$

此概率已归一化，即 $\sum_{G,\{s_i\}} P(G,\{s_i\}\mid\theta)=1$。现在假设已知图 G 和参数 θ，希望求群组赋值上的概率分布。用 Bayes 公式，

$$\begin{aligned} P(\{s_i\}\mid G,\theta) &= \frac{P(G,\{s_i\}\mid\theta)}{\sum_{\{t_i\}}P(G,\{t_i\}\mid\theta)} \\ &= \frac{1}{Z_G}\prod_{i<j}\left[(c_{s_i,s_j})^{A_{ij}}\left(1-\frac{c_{s_i,s_j}}{N}\right)^{1-A_{ij}}\right]\prod_i n_{s_i}. \end{aligned} \tag{10.6}$$

前面的定理 12 告诉我们，为最大化真值赋值与估计 $\widehat{s}_i$ 之间的重叠 Q，需要计算

$$\widehat{s}_i = \operatorname*{argmax}_{s_i} \mu_i(s_i), \tag{10.7}$$

其中 $\mu_i(t_i)$ 是后验分布的边缘概率；回顾 $\mu_i(s_i)=\sum_{\{s_j\}_{j\neq i}} P(\{s_i\}\mid G,\theta)$。

注意，该最优决策估计量与寻找后验概率最大构型的最大似然估计量有关键区别。在 SBM 所考虑的高维 $N\to\infty$ 含噪设定中，相对于与真值构型的重叠，最大似然估计量是次优的。还要注意，后验在群组标签置换下对称，因此整个分布的边缘是均匀的。然而，后面将看到，社区可检测时，这一置换对称性破缺，边缘化给出式 (10.4) 所定义重叠的最优估计，其中对所有置换取最大值。**译注：**源文把“后验最大构型”称为最大似然；一般先验下这与 MAP/最大似然仍需区分。后验对标签置换对称且单点边缘均匀，也要求相应对称参数或同时置换参数，并非任意已知 n_a, c_{ab} 均成立。逐点最优类别决策与最大化整体置换后重叠的联系还需明确选择对称性分支；保留源文结论与其后续语境。

若图 G 确实由参数值为 θ 的 SBM 生成，则前述 Nishimori 恒等式成立。其结果是：在热力学极限，即使不知道原赋值 $\{s_i^*\}$，也可以计算重叠。由 Nishimori 恒等式，

$$\lim_{N\to\infty}\frac{N^{-1}\sum_i \mu_i(\widehat{s}_i)-\max_a n_a}{1-\max_a n_a} = \lim_{N\to\infty} Q(\{\widehat{s}_i\},\{s_i^*\}). \tag{10.8}$$

边缘 $\mu_i(q_i)$ 还可用于区分强烈偏好某群组的节点，与群组归属尚不确定的节点。

Nishimori 恒等式的另一结果是：从后验随机抽取的两个构型之间的一致度，与其中一个构型和原赋值 s_i^* 之间的一致度相同，即

$$\lim_{N\to\infty}\frac{1}{N}\max_{\pi}\sum_i \mu_i(\pi(s_i^*)) = \lim_{N\to\infty}\frac{1}{N}\sum_a\sum_i \mu_i(a)^2. \tag{10.9}$$

其中 π 仍遍历 q 个元素的所有置换。总体而言，Nishimori 恒等式表明，真值构型 s^* 与按后验测度随机抽取的任意构型具有完全相同的性质。因此，可以用真值构型探测后验的平衡性质；回到图着色问题时将大量使用这一点。**译注：**以上极限式的成立需相应无序平均 / 集中与标签对齐条件，不能单凭有界函数的 Nishimori 恒等式，直接取消平均并穿过最大化；$\mu_i(q_i)$ 的 q_i 为源文记法。

10.2.2 学习参数

现在假设只知道图 G，而不知道参数 θ。贝叶斯推断的一般目标是根据已知数据，学习底层模型最可能的参数值。这里参数为 $\theta = \{q, \{n_a\}, \{c_{ab}\}\}$，数据为图 G，更确切地说是邻接矩阵 A_{ij}。按 Bayes 公式，给定 G 后参数取某值的概率 $P(\theta \mid G)$，正比于参数为 θ 的模型生成 G 的概率 $P(G \mid \theta)$；后者又是 $P(G, \{s_i\} \mid \theta)$ 对所有群组赋值的和：

$$P(\theta \mid G) = \frac{P(\theta)}{P(G)}P(G \mid \theta) = \frac{P(\theta)}{P(G)}\sum_{\{s_i\}} P(G, \{s_i\} \mid \theta). \tag{10.10}$$

先验 $P(\theta)$ 包含所有与图无关的参数信息。在这里，希望对参数完全保持中立，例如不让推断偏向同配结构，因此假定均匀先验，即忽略归一化后 $P(\theta) = 1$。不过，式 (10.10) 中的和通常随 N 指数增长，因此只要平滑先验不依赖于 N，也可以采用任意这样的 $P(\theta)$；大 N 时，数据会使先验影响消失，留下与均匀先验相同的分布。因此，对 θ 最大化 $P(\theta \mid G)$，等价于对 θ 最大化配分函数，也等价于最大化自由能熵。**译注：**这里“自由能熵”沿用源文的 free energy entropy 措辞；先验影响消失需其在相关主导参数附近非零等条件，不能据指数尺度单独推出任意模型、未识别参数或次主导阶下的完全相同后验。参数空间的归一化范围也未在此明确。

10.3 SBM 的信念传播

现在对概率分布 (10.6) 写出前面推导的信念传播方程。该分布对应完全连接的因子图，而我们此前强调，BP 为树设计，并在局部树状图上效果良好。不过，之所以需要局部树状图，主要是为了假设传入消息独立；如果每条传入消息只微弱影响发出消息，所需的独立性条件便可减弱。事实上，已研究的 Curie–Weiss 模型、低秩矩阵估计等结果也可从 BP 推导。在 Curie–Weiss 模型中，相互作用很弱，每个邻居以反比于 N 的强度影响磁化。分布 (10.6) 则混合了两部分：边对应 $O(1)$ 的项，并组织成局部树状图；非边项稠密，但每条相互作用强度与 N 成反比。因此，它是稀疏与稠密图模型结合的有趣例子。

该图模型的标准 BP 方程为

$$\chi_{t_i}^{i\to j} = \frac{1}{Z^{i\to j}} n_{t_i}\prod_{k\neq i,j}\left[\sum_{t_k} c_{t_i t_k}^{A_{ik}}\left(1-\frac{c_{t_i t_k}}{N}\right)^{1-A_{ik}}\chi_{t_k}^{k\to i}\right], \tag{10.11}$$

其中 $Z^{i\to j}$ 是使 $\sum_{t_i}\chi^{i\to j}_{t_i}=1$ 的归一化常数。消息可解释为移除因子 ij 后，节点 i 属于群组 t_i 的边缘概率。BP 假定，i 的邻居之间的关联仅由 i 传递，因此移除 i 或固定其标签后，邻居状态的分布为乘积分布。这样，就能由 i 从其他邻居 k 收到的消息递推算出其发往 j 的消息。

在 BP 不动点处，边缘概率估计为 $\mu_i(t_i)\approx\chi^i_{t_i}$，其中

$$\chi^i_{t_i}=\frac{1}{Z^i}n_{t_i}\prod_{k\neq i}\left[\sum_{t_k}c_{t_it_k}^{A_{ik}}\left(1-\frac{c_{t_it_k}}{N}\right)^{1-A_{ik}}\chi^{k\to i}_{t_k}\right]. \tag{10.12}$$

每对节点之间都有非零相互作用，故潜在共有 $N(N-1)$ 条消息，式 (10.11) 给出有限 N 时全部消息的更新。但一次更新便需 $O(N^2)$ 时间，因此只适合几千节点以内的网络。对大型稀疏网络，N 很大且 $c_{ab}=O(1)$，可以忽略 N 的次主导阶项。此时可假设 i 对所有非邻居 j 发出相同消息，将其作为外场处理，只需跟踪 $2M$ 条消息，其中 M 为边数，每次更新只需 $O(M)=O(N)$ 时间。

为此，先设 $(i,j)\notin E$，有

$$\begin{aligned}\chi^{i\to j}_{t_i}&=\frac{1}{Z^{i\to j}}n_{t_i}\prod_{k\notin\partial i\setminus j}\left[1-\frac{1}{N}\sum_{t_k}c_{t_kt_i}\chi^{k\to i}_{t_k}\right]\prod_{k\in\partial i}\left[\sum_{t_k}c_{t_kt_i}\chi^{k\to i}_{t_k}\right]\\&=\chi^i_{t_i}+O(1/N).\end{aligned} \tag{10.13}$$

因此，在主导阶上非边消息不依赖于目标节点 j。另一方面，对 $(i,j)\in E$，

$$\chi^{i\to j}_{t_i}=\frac{1}{Z^{i\to j}}n_{t_i}\prod_{k\notin\partial i}\left[1-\frac{1}{N}\sum_{t_k}c_{t_kt_i}\chi^{k\to i}_{t_k}\right]\prod_{k\in\partial i\setminus j}\left[\sum_{t_k}c_{t_kt_i}\chi^{k\to i}_{t_k}\right]. \tag{10.14}$$

因此可将 BP 方程改写为

$$\chi^{i\to j}_{t_i}=\frac{1}{Z^{i\to j}}n_{t_i}e^{-h_{t_i}}\prod_{k\in\partial i\setminus j}\left[\sum_{t_k}c_{t_kt_i}\chi^{k\to i}_{t_k}\right], \tag{10.15}$$

其中忽略了对 $\chi^{i\to j}$ 贡献为 $O(1/N)$ 的项，并定义辅助外场，将非边的总体影响汇总为

$$h_{t_i}=\frac{1}{N}\sum_k\sum_{t_k}c_{t_kt_i}\chi^k_{t_k}. \tag{10.16}$$

为在线性时间内求得式 (10.15) 的不动点，更新 $\chi^{i\to j}$，重算 χ^j，并通过加上新贡献、减去旧贡献来更新 h_{t_i}，随后重复。边缘概率 $\mu_i(t_i)$ 的估计为

$$\chi^i_{t_i}=\frac{1}{Z^i}n_{t_i}e^{-h_{t_i}}\prod_{j\in\partial i}\left[\sum_{t_j}c_{t_jt_i}\chi^{j\to i}_{t_j}\right]. \tag{10.17}$$

磁场 h_{t_i} 在 BP 更新中的作用类似于群组大小先验 n_{t_i}。不同的是，n_{t_i} 固定，而 h_{t_i} 随当前群组大小估计自适应变化。对同配社区，这一项至关重要：若某群组 a 被过多表示，h_a 便增大，削弱所有 χ_a 消息。因此，该场自适应地保持正确群组大小，避免所有节点落入同一群组。异配情形中，它同样调节群组大小。一个特殊情况是群组大小相同、各组平均度也相同的异配结构，此时 $e^{-h_{t_i}}$ 不改变 BP 行为；这将成为映射到植入着色问题的基础。

若 BP 渐近精确，则真实边缘为 $\mu_i(t_i) = \chi^i_{t_i}$，最大化重叠的估计量为

$$\widehat{s}_i = \operatorname*{argmax}_{t_i} \chi^i_{t_i}. \tag{10.18}$$

假设采用的参数 θ 的确是生成图时的参数，利用式 (10.8)，与原赋值的重叠可算为

$$Q = \lim_{N\to\infty} \frac{N^{-1}\sum_i \chi^i_{\widehat{s}_i} - \max_a n_a}{1 - \max_a n_a}. \tag{10.19}$$

为写出 Bethe 自由熵，作类似简化并忽略次主导阶项。定义

$$Z^{ij} = \sum_{a<b} c_{ab}(\chi^{i\to j}_a \chi^{j\to i}_b + \chi^{i\to j}_b \chi^{j\to i}_a) + \sum_a c_{aa}\chi^{i\to j}_a \chi^{j\to i}_a, \quad (i,j)\in E, \tag{10.20}$$

$$\widetilde{Z}^{ij} = \sum_{a,b}\Big(1 - \frac{c_{ab}}{N}\Big)\chi^i_a \chi^j_b, \quad (i,j)\notin E, \tag{10.21}$$

$$Z^i = \sum_{t_i} n_{t_i} e^{-h_{t_i}} \prod_{j\in\partial i}\sum_{t_j} c_{t_j t_i}\chi^{j\to i}_{t_j}. \tag{10.22}$$

在热力学极限，Bethe 自由熵为

$$\Phi_{\mathrm{BP}}(q,\{n_a\},\{c_{ab}\}) = \frac{1}{N}\sum_i \log Z^i - \frac{1}{N}\sum_{(i,j)\in E}\log Z^{ij} + \frac{c}{2}, \tag{10.23}$$

其中 c 为式 (10.2) 的平均度，第三项来自非边的边贡献，即 $\sum_{i,j}\log\widetilde{Z}^{ij}$。推导此表达式作为课后习题。

假设模型参数 θ 已知，因而 Nishimori 条件成立，现在可对 $N\to\infty$ 渐近极限下 BP 的精确性提出一个猜想：对应最大 Bethe 自由熵的 BP 不动点，按以下意义给出 SBM 的贝叶斯最优估计量。

- Bethe 自由熵 Φ_{BP} 精确，即对所有 $\varepsilon > 0$，

  $$|\Phi_{\mathrm{BP}}(\theta) - \Phi_{\mathrm{exact}}(\theta)| < \varepsilon, \tag{10.24}$$

  当 $N\to\infty$ 时，对模型随机性以高概率成立。

- 对应 BP 重叠等于贝叶斯最优估计量所得重叠：对所有 $\varepsilon > 0$，

  $$|Q_{\mathrm{BP}} - Q_{\mathrm{BO}}| < \varepsilon, \tag{10.25}$$

  当 $N\to\infty$ 时，对模型随机性以高概率成立。

- 除趋于零比例的节点外，BP 边缘均正确：对所有 $\varepsilon > 0$，

  $$|\chi^i_{s_i} - \mu_i(s_i)| < \varepsilon, \tag{10.26}$$

  当 $N\to\infty$ 时，以高概率对几乎所有 $i = 1,\dots,N$ 成立。

译注：以上三条是原文明确提出的猜想，本轮保留其地位，未升级为定理或对任意参数、任意 BP 不动点的证明。

参数 θ 未知、需要学习时，Bethe 自由能也十分有用。前面已得出，最可能的参数最大化 Bethe 自由熵。因此，可直接对参数运行梯度下降以最大化 Bethe 熵。更方便的是，写出 Bethe 自由熵关于 n_a, c_{ab} 的驻点条件，并用作参数估计的迭代过程。记住 BP 不动点是 Bethe 自由熵驻点，同时 n_a 需满足 $\sum_a n_a = 1$，因此寻找的是约束最优解，得到

$$n_a = \frac{1}{N}\sum_i \chi_a^i, \tag{10.27}$$

$$c_{ab} = \frac{1}{N}\frac{1}{n_b n_a}\sum_{(i,j)\in E}\frac{c_{ab}(\chi_a^{i\to j}\chi_b^{j\to i} + \chi_b^{i\to j}\chi_a^{j\to i})}{Z^{ij}}, \tag{10.28}$$

其中 Z^{ij} 由式 (10.20) 定义。推导作为课后习题。这些式子也有直观解释，同样来自贝叶斯最优估计的 Nishimori 恒等式：第一式说，群组 a 的节点比例应等于 BP 预测的群组 a 节点数期望；类似地，第二式要求，群组 a, b 之间的边数期望与由 BP 边缘计算的值相同。因此，BP 也可直接用来学习最优参数。**译注：**原文说用 “梯度下降” 最大化目标，需明确是下降负目标还是上升原目标；参数迭代也不单凭驻点条件保证全局最优或收敛。$a = b$ 时的无序边计数、归一化及参数约束需单独核查，原式 (10.28) 保留。

10.4 社区发现的相图

现在假设生成网络时使用的参数 $q, \{n_a\}, \{c_{ab}\}$ 已知，并进一步限制到算法上特别困难的一类块模型：每个群组的平均度相同，均为 c，因此仅从度分布无法得到群组赋值信息。条件为

$$\sum_{d=1}^{q} c_{ad} n_d = \sum_{d=1}^{q} c_{bd} n_d = c, \qquad \forall a, b. \tag{10.29}$$

否则，仅根据节点度标记，就能获得与原赋值的正重叠。对 BP 方程 (10.15)，首先观察到

$$\chi_{t_i}^{i\to j} = n_{t_i} \tag{10.30}$$

始终是不动点，代回即可验证。该不动点的自由熵为

$$\Phi_{\text{para}} = -\frac{c}{2}(1 - \log c). \tag{10.31}$$

边缘为 $\chi_{t_i}^{i} = n_{t_i}$，从式 (10.8) 得到 $Q = 0$。这一不动点不给出原赋值的任何信息，并不优于随机猜测。若它给出的边缘和自由熵确实正确，就无法恢复原群组赋值。对哪些 q, n_a, c_{ab} 值会如此?

10.4.1 二阶相变

图 10.4.1 给出两个例子，在随机生成的图上计算重叠 Q，图有 q 个等大群组，平均度为 c。取 $c_{aa} = c_{\text{in}}$，所有 $a \neq b$ 取 $c_{ab} = c_{\text{out}}$，并改变比值 $\epsilon = c_{\text{out}}/c_{\text{in}}$。连续曲线来自随机初值收敛得到的 BP 不动点；对每对 i, j，初始消息 $\chi_{t_i}^{i\to j}$ 为 t_i 上的随机归一化分布。收敛时间见图 10.4.2。图 10.4.1 中的点来自 Gibbs 采样，采用 Metropolis 规则，对后验满足细致平衡，并从随机初始群组赋值 $\{q_i\}$ 出发。

当 $c_{\text{out}}/c_{\text{in}} > \epsilon_c$ 时，$Q = 0$。即在该区域，BP 与 MCMC 都收敛到顺磁态，边缘中不含原赋值信息。反之，$c_{\text{out}}/c_{\text{in}} < \epsilon_c$ 时重叠为正，BP 或 MCMC 不再收敛到顺磁不动点。

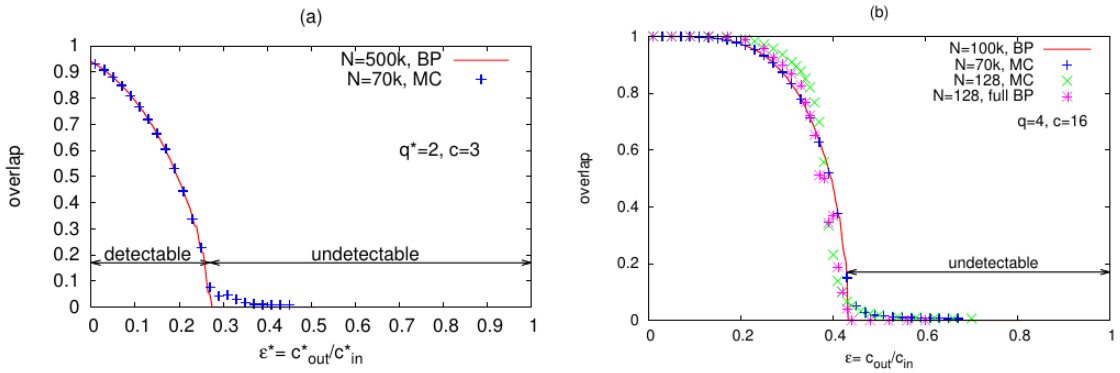


图 10.4.1: 原赋值与根据图结构得到的最佳估计之间的重叠 (10.4)，通过边缘化 (10.7) 计算。图由 N 个节点、q 个等大群组、平均度 c 及不同 $\epsilon = c_{\text{out}}/c_{\text{in}}$ 生成；$\epsilon = 1$ 给出 Erdős–Rényi 随机图，$\epsilon = 0$ 给出完全分离的群组。比较大图的稀疏 BP (10.15)（红线）与 Gibbs / MCMC 采样（数据点），吻合良好；低重叠区域的差别归因于有限大小涨落。(b) 还比较 $N = 128$ 小图上的完整 BP (10.11) 与 MCMC，平均 400 个样本。有限大小效应不很强；即使小图有许多短回路，BP 仍较接近精确（MCMC）结果。$N \to \infty$ 且 $\epsilon > \epsilon_c = (c - \sqrt{c})/[c + \sqrt{c}(q-1)]$ 时，仅由图结构无法找到与原赋值相关的赋值。对两个群组、$c = 3$，要得到正重叠，组内连接密度需为组间的 $\epsilon_c^{-1} = 3.73$ 倍。图中 detectable/undetectable 分别为可检测 / 不可检测。

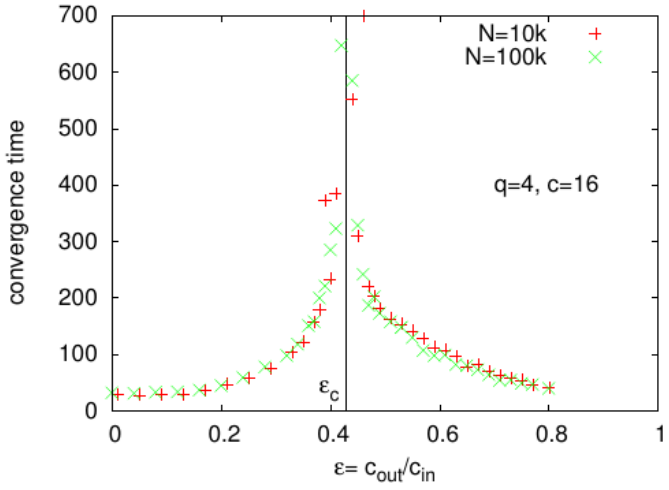


图 10.4.2: 两种系统大小下 BP 收敛所需的迭代次数。在临界点 ϵ_c 处收敛时间发散。Gibbs / MCMC 的平衡时间有定性相同的行为，但 BP 获得边缘的速度快得多。图中 convergence time 为收敛时间。

图 10.4.1(b) 为 $q=4, c=16$ 的情形，既给出大 N 结果，也给出很小系统 $N=128$ 的 MCMC 重叠。除对称性破缺外，边缘化再次达到任何算法从图中所能推断的最佳重叠。 **译注：** 图中算法和有限样本比较保留为原作者数值观察；MCMC 是否已平衡及误差控制未由本次翻译重新认证。上述不可检测结论的图系综和参数范围按本小节两个例子理解，不从图注扩展到任意非对称或多群组模型。

10.4.2 顺磁不动点的稳定性

考察迭代 BP 时，消息受到随机扰动后的顺磁不动点稳定性。稀疏情形 $c_{ab}=O(1)$ 下，块模型生成的图局部树状：几乎所有节点在 $O(\log N)$ 距离内有树形邻域，其中常数依赖矩阵 c_{ab}。等价地，几乎所有节点 i 所属的最短回路长度为 $O(\log N)$。考虑有 d 层的树并取 $d\to\infty$。假设叶节点上的顺磁不动点受到扰动：

$$\chi_t^k = n_t + \varepsilon_t^k, \tag{10.32}$$

考察它对根节点 k_0 消息的影响。树平均有 c^d 个叶节点，每个叶节点的影响独立。先考虑一个叶节点 k_d，通过路径 $k_d, k_{d-1}, \dots, k_1, k_0$ 连接到根。定义一种传递矩阵

$$\begin{aligned} T_{ab}^i &:= \left.\frac{\partial \chi_a^{k_i}}{\partial \chi_b^{k_{i+1}}}\right|_{\chi_t=n_t} \\ &= \left[\frac{\chi_a^{k_i} c_{ab}}{\sum_r c_{ar}\chi_r^{k_{i+1}}} - \chi_a^{k_i}\sum_s \frac{\chi_s^{k_i} c_{sb}}{\sum_r c_{sr}\chi_r^{k_{i+1}}}\right]_{\chi_t=n_t} = n_a\left(\frac{c_{ab}}{c}-1\right). \end{aligned} \tag{10.33}$$

该式由 (10.15) 在 N 主导阶得到。叶节点扰动对根的影响为

$$\varepsilon_{t_0}^{k_0} = \sum_{\{t_i\}_{i=1,\dots,d}} \left[\prod_{i=0}^{d-1} T^i_{t_i,t_{i+1}}\right] \varepsilon_{t_d}^{k_d}. \tag{10.34}$$

矩阵 T_{ab}^i 不依赖于 i，故可写为 $\varepsilon^{k_0} = T^d \varepsilon^{k_d}$。$d\to\infty$ 时，T^d 由 T 最大本征值 λ 主导，因此 $\varepsilon^{k_0} \approx \lambda^d \varepsilon^{k_d}$。

再考虑所有 c^d 个叶节点。叶上的扰动均值为零，因此根上影响的均值也为零；但方差为

$$\left\langle (\varepsilon_{t_0}^{k_0})^2 \right\rangle \approx \left\langle \left(\sum_{k=1}^{c^d} \lambda^d \varepsilon_t^k\right)^2 \right\rangle \approx c^d \lambda^{2d} \langle (\varepsilon_t^k)^2 \rangle. \tag{10.35}$$

由此得到稳定性判据

$$c\lambda^2 = 1. \tag{10.36}$$

$c\lambda^2<1$ 时，向树根传播的叶扰动消失，顺磁不动点稳定；$c\lambda^2>1$ 时，扰动指数放大，顺磁不动点失稳，社区容易检测。

考虑 q 个等大群组，$c_{aa}=c_{\rm in}$，$a\neq b$ 时 $c_{ab}=c_{\rm out}$，则 $c_{\rm in}+(q-1)c_{\rm out}=qc$。传递矩阵只有两种不同本征值：$\lambda_1=0$，本征向量为 $(1,1,\dots,1)$；以及 $q-1$ 重简并的 $\lambda_2=(c_{\rm in}-c_{\rm out})/(qc)$，本征向量形如 $(0,\dots,0,1,-1,0,\dots,0)$。因此，当

$$|c_{\rm in}-c_{\rm out}| > q\sqrt{c} \tag{10.37}$$

时，顺磁不动点不稳定，社区容易检测。

式 (10.36) 在自旋玻璃文献中称为 de Almeida–Thouless 局域稳定性条件（de Almeida and Thouless, 1978），在信息科学中称为树重构的 Kesten–Stigum 界（Kesten and Stigum, 1967）。

经验上，随机初值下，$c\lambda^2 < 1$ 时 BP 收敛到顺磁不动点；$c\lambda^2 > 1$ 时，BP 收敛到正重叠不动点，从而可找到与原赋值相关、往往强相关的群组赋值。因此，参数已知且 $c\lambda^2 > 1$ 时，可以重构原群组赋值。对图 10.4.1 的情形，可分两相：

- $|c_{\text{in}} - c_{\text{out}}| < q\sqrt{c}$ 时，图不含原群组赋值的显著信息，社区发现不可能；块模型生成的网络也无法与同平均度的 Erdős–Rényi 随机图区分。
- $|c_{\text{in}} - c_{\text{out}}| > q\sqrt{c}$ 时，图包含显著赋值信息，BP 或 MCMC 给出与原赋值强相关的结果。熵仍带来固有不确定性，但如果图确由块模型生成，则没有优于式 (10.7) 边缘化的推断方法。

因此，图 10.4.1 展示社区可检测性的相变。除非 $c_{\text{out}}/c_{\text{in}}$ 与 1 足够远，生成网络时真实存在的群组就无法由网络拓扑检测。此外，若不满足式 (10.37)，块模型图便无法与随机图区分，其含义是两个系综的典型热力学性质相同。**译注：**局部树状半径 / 最短回路陈述仍需区分树分量和常数范围；稳定性中的“最大本征值”应结合归一化扰动空间及模理解。此处“重构”指前述正重叠检测，不等于逐节点精确恢复。线性稳定性本身不证明任意参数下的全局不可检测，原文下一节还讨论其他不动点与一阶相变。

10.4.3 一阶相变

图 10.4.1 所示连续二阶相变并非最一般情形。图 10.4.3 展示不连续一阶相变，例如 $q = 5, c_{\text{in}} = 0, c_{\text{out}} = qc/(q-1)$。此时稳定性条件 (10.37) 给出阈值 $c_\ell = (q-1)^2$。再次绘制 BP 重叠，采用两种初始化：随机初始化，以及与原赋值对应的植入 / 知情初始化。后者的初始消息为

$$\chi_{q_i}^{i\to j} = \delta_{q_i, s_i^*}, \tag{10.38}$$

其中 s_i^* 为原赋值。同时绘出对应 BP 自由能。随着平均度 c 增大，图中出现四个相。

I. $c < c_d$ 时，两种初始化都收敛到顺磁不动点，因此图不含原赋值的显著信息。

II. $c_d < c < c_c$ 时，植入初始化收敛到正重叠不动点，其自由熵小于顺磁自由熵。在群组间边数适当的赋值空间中，存在指数多个吸引盆（态）。这些吸引盆彼此重叠为零，因此任何一个都不给出其他吸引盆的信息，无法判断哪一个包含原赋值。顺磁自由熵仍是正确的总自由熵，块模型图在热力学上与 Erdős–Rényi 随机图不可区分，无法找到与原赋值相关的群组赋值。

III. $c_c < c < c_\ell$ 时，植入初始化收敛到正重叠不动点，其自由熵大于顺磁自由熵。满足组间边数的状态空间中，可能仍有指数多个吸引盆，但原赋值对应的吸引盆具有最大自由熵。因此，若能穷举状态空间，就能推断原赋值；但这需要指数时间，随机初始化 BP 几乎总是落到顺磁不动点。在该相中，推断在信息上可能，但猜想计算上需要指数时间。

IV. $c > c_\ell$ 时，两种初始化都收敛到正重叠、与原赋值强相关的不动点。因此推断既可能又可处理，BP 以线性时间实现它。

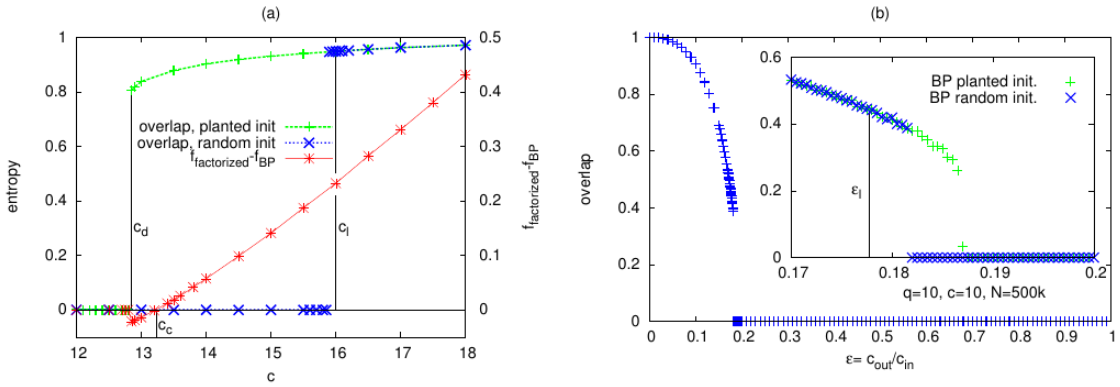


图 10.4.3: (a) $q=5, c_{\text{in}}=0, N=10^5$ 的图，计算不同平均度 c 下的 BP 重叠 (10.4) 与自由能。绿色叉号为以原赋值初始化所得不动点的重叠，蓝色叉号为随机消息初始化结果。红星为顺磁自由能 (10.31) 与知情初始化所得自由能之差。三个行为定性变化点为 $c_d=12.84, c_c=13.23, c_\ell=16$，正文讨论相应相变。(b) $q=10, c=10$ 时重叠随 ϵ 的变化，约从 $Q=0.35$ 处突然下降。插图放大临界区域，标出稳定性转变 ϵ_ℓ；数据为 $N=5\cdot 10^5$ 下随机与知情初始化的结果。这里数据不很清楚：随机初始化重叠在渐近转变之前略微变正，作者认为由强有限大小效应导致。自由能数据还提示 ϵ_c, ϵ_d 很接近，甚至可能相等，尽管这令人意外。这些细微效应仅存在于很窄的 ϵ 区域，作者认为它们不太可能在现实网络中出现。图中 planted/random init 分别为植入 / 随机初始化。

实验中，同配社区 $c_{\text{in}} > c_{\text{out}}$ 的相 II、III 极窄或不存在。$q \le 4$ 时，这两个相完全不存在，重叠在相 IV 中从零连续增长，得到图 10.4.1 的连续相变。可将连续二阶相变视为一阶相变的退化情况，三个阈值相同：$c_d = c_c = c_\ell$。$q \ge 5$ 时，相 II、III 存在，但区间极窄，如图 10.4.3(b)；重叠从零不连续跳到较大值，形成不连续相变。

异配（反铁磁）情形 $c_{\text{in}} < c_{\text{out}}$ 中，相 II、III 更重要。例如 $c_{\text{in}}=0$ 且群组数很大时，阈值按 $c_d \approx q\log q$、$c_c \approx 2q\log q$、$c_\ell = (q-1)^2$ 缩放。但相 III 中推断原赋值很困难，猜想所有多项式时间算法在该区域都无法克服这一困难。**译注：**原文关于吸引盆、阈值与线性时间算法的表述保留其给定系综、实验或猜想范围；“猜想指数困难”没有译成已证明的复杂性下界，也不把知情初始化当作未知真值时可直接使用的算法。

10.4.4 非回溯矩阵与谱方法

既然 BP 和 MCMC 都能达到算法阈值 c_ℓ，自然要问哪些其他算法也能做到。基于相关矩阵主导本征值的谱方法，例如主成分分析，常用于聚类。但稀疏图社区发现中，常用谱方法大多不能达到阈值，因为其主导本征向量会局域在与社区无关的子图上；例如大型稀疏图的邻接矩阵谱会局域在高度节点附近。

设计达到最优阈值谱方法的一个普遍而有力的思路，是注意到：最初通过在顺磁不动点附近线性化 BP，已算出了 c_ℓ。令 $\chi_t^{i\to j} = n_t + \varepsilon_t^{i\to j}$，得到

$$\varepsilon_t^{i\to j} = \sum_{k\in\partial i\setminus j}\sum_q \left.\frac{\partial \chi_t^{i\to j}}{\partial \chi_q^{k\to i}}\right|_{\chi_q^{k\to i}=n_q} \varepsilon_q^{k\to i} = \sum_{k\in\partial i\setminus j}\sum_q T_{tq}\varepsilon_q^{k\to i}, \tag{10.39}$$

其中 T 已在式 (10.33) 中计算。引入所谓非回溯矩阵，它是 $2M \times 2M$ 矩阵（M 为边数），坐标对应有向边：

$$B_{i\to j,k\to \ell} = \delta_{i,\ell}(1-\delta_{j,k}). \tag{10.40}$$

线性化 BP 可写为

$$\varepsilon = (T \otimes B)\varepsilon. \tag{10.41}$$

因此，线性化 BP 对应小型 $q\times q$ 矩阵 T 与非回溯矩阵 B 的张量积上的幂迭代。B 的谱确实提供比其他常见谱方法更准确的社区信息，并在稀疏 SBM 中达到可检测阈值。

10.5 习题

习题 10.1：SBM 自由能

证明随机块模型的 Bethe 自由熵可用

$$Z^{ij} = \sum_{a<b} c_{ab}(\chi_a^{i\to j}\chi_b^{j\to i} + \chi_b^{i\to j}\chi_a^{j\to i}) + \sum_a c_{aa}\chi_a^{i\to j}\chi_a^{j\to i}, \quad (i,j)\in E, \tag{10.42}$$

$$Z^i = \sum_{t_i} n_{t_i} e^{-h_{t_i}} \prod_{j\in\partial i}\sum_{t_j} c_{t_j t_i}\chi_{t_j}^{j\to i} \tag{10.43}$$

写为

$$\Phi_{\mathrm{BP}}(q,\{n_a\},\{c_{ab}\}) = \frac{1}{N}\sum_i \log Z^i - \frac{1}{N}\sum_{(i,j)\in E}\log Z^{ij} + \frac{c}{2}, \tag{10.44}$$

其中 c 为式 (10.2) 给出的平均度。

习题 10.2：用 BP 学习参数

证明，在随机块模型中，在 BP 不动点处关于参数 n_a, c_{ab} 最大化 Bethe 自由熵，给出如下驻点条件，可用于迭代学习这些参数：

$$n_a = \frac{1}{N}\sum_i \chi_a^i, \tag{10.45}$$

$$c_{ab} = \frac{1}{N}\frac{1}{n_b n_a}\sum_{(i,j)\in E}\frac{c_{ab}(\chi_a^{i\to j}\chi_b^{j\to i} + \chi_b^{i\to j}\chi_a^{j\to i})}{Z^{ij}}. \tag{10.46}$$

11 从稀疏图到稠密图的自旋玻璃博弈

他发牌，如同冥想；

与他对局的人从不怀疑。

他并非为了赢来的钱，

也不是为了赢得尊重。

他发牌，是为寻找答案，

偶然之中神圣的几何，

可能结果背后隐藏的规律，

数字引领着一场舞蹈。

Sting，《Shape of My Heart》，1993

11.1 自旋玻璃博弈

考虑如下问题：N 个人各得到一张红牌或黑牌，等价地具有取值 $S_i^* = \pm 1$。可以随机询问 M 对人，让他们告诉你两人的牌是否同色，但不告诉具体是哪一种。能找出这两个群组吗?

用贝叶斯统计可形式化回答。给定 M 个回答 $J_{ij} = \pm 1$（同色为 1，异色为 -1），后验赋值概率为

$$P_{\text{post}}(S \mid J) = \frac{1}{\mathcal{N}} P_{\text{post}}(J \mid S) P_{\text{prior}}(S) = \frac{1}{\mathcal{N} 2^N} \prod_{ij \in G} P(J_{ij} = S_i S_j), \tag{11.1}$$

其中图 G 在被询问的两人之间连边。有些人不可信，记说谎概率为 p，则

$$P_{\text{post}}(S \mid J) = \frac{1}{\mathcal{N} 2^N} \prod_{ij \in G} [(1-p)\delta(J_{ij} = S_i S_j) + p\delta(J_{ij} = -S_i S_j)]. \tag{11.2}$$

变量替换 $p = e^{-\beta}/(e^{-\beta} + e^{\beta}) = 1/(1 + e^{2\beta})$ 后，得到

$$P_{\text{post}}(S \mid J) = \frac{1}{Z} e^{\beta \sum_{ij \in G} J_{ij} S_i S_j}. \tag{11.3}$$

这就是 Hamiltonian $\mathcal{H} = -\sum J_{ij} S_i S_j$ 的自旋玻璃问题，因此称这一特定推断问题为“自旋玻璃博弈”。

11.2 稀疏图

11.2.1 信念传播

先讨论稀疏图。当 $N, M \to \infty$ 时，有随机局部树状正则图，因此可以写出 BP 方程。使用附录 5.A 的两体模型结果，每条边对应一个因子，BP 方程为

$$\chi_{s_j}^{j \to (ij)} = \frac{1}{Z^{j \to (ij)}} \prod_{(kj) \in \partial j \setminus (ij)} \psi_{s_j}^{(kj) \to j}, \tag{11.4}$$

$$\psi_{s_i}^{(ij) \to i} = \frac{1}{Z^{(ij) \to i}} \sum_{s_j} e^{\beta J_{ij} s_i s_j} \chi_{s_j}^{j \to (ij)}. \tag{11.5}$$

方便的参数化为

$$\chi_{s_j}^{j \to (ij)} = \frac{1 + s_j m^{j \to (ij)}}{2}, \tag{11.6}$$

$$\psi_{s_i}^{(ij) \to i} = \frac{e^{\beta s_i h^{(ij) \to i}}}{2 \cosh(\beta h^{(ij) \to i})}, \tag{11.7}$$

由此

$$m^{j\to(ij)} = \tanh\left(\beta \sum_{(kj)\in\partial j\setminus(ij)} h^{(kj)\to j}\right), \tag{11.8}$$

$$\frac{e^{\beta s_i h^{(ij)\to i}}}{2\cosh(\beta h^{(ij)\to i})} = \frac{1}{Z^{(ij)\to i}} \sum_{s_j} e^{\beta J_{ij} s_i s_j} \frac{1+s_j m^{j\to(ij)}}{2}. \tag{11.9}$$

第二式还可等价写为

$$\tanh(\beta h^{(ij)\to i}) = \frac{X_+ - X_-}{X_+ + X_-}, \tag{11.10}$$

$$X_s = \sum_{s_j} e^{\beta J_{ij} s s_j} \frac{1+s_j m^{j\to(ij)}}{2}, \tag{11.11}$$

$$= \frac{1}{2} e^{\beta s J_{ij}} (1 + m^{j\to(ij)}) + \frac{1}{2} e^{-\beta s J_{ij}} (1 - m^{j\to(ij)}). \tag{11.12}$$

利用关系 $\operatorname{atanh} y = \frac{1}{2}\log\frac{1+x}{1-x}$，在两边取反双曲正切，得到

$$\beta h^{(ij)\to i} = \frac{1}{2}\log\frac{X_+}{X_-}, \tag{11.13}$$

$$= \frac{1}{2}\log\frac{e^{\beta J_{ij}}(1+m^{j\to(ij)}) + e^{-\beta J_{ij}}(1-m^{j\to(ij)})}{e^{-\beta J_{ij}}(1+m^{j\to(ij)}) + e^{\beta J_{ij}}(1-m^{j\to(ij)})}, \tag{11.14}$$

$$= \frac{1}{2}\log\frac{\cosh(\beta J_{ij}) + m^{j\to(ij)}\sinh(\beta J_{ij})}{\cosh(\beta J_{ij}) - m^{j\to(ij)}\sinh(\beta J_{ij})}, \tag{11.15}$$

$$= \frac{1}{2}\log\frac{1 + m^{j\to(ij)}\tanh(\beta J_{ij})}{1 - m^{j\to(ij)}\tanh(\beta J_{ij})}, \tag{11.16}$$

$$= \operatorname{atanh}\big(m^{j\to(ij)}\tanh(\beta J_{ij})\big). \tag{11.17}$$

最终，BP 可更方便地写为

$$m^{j\to(ij)} = \tanh\left(\beta \sum_{(kj)\in\partial j\setminus(ij)} h^{(kj)\to j}\right), \tag{11.18}$$

$$h^{(ij)\to i} = \frac{1}{\beta}\operatorname{atanh}\big(m^{j\to(ij)}\tanh(\beta J_{ij})\big). \tag{11.19}$$

更进一步，$m^{j\to(ij)}$ 可无歧义地写成 $m^{j\to i}$，因此

$$m^{j\to i} = \tanh\left(\sum_{k\in\partial j\setminus i} \operatorname{atanh}(m^{k\to j}\tanh(\beta J_{kj}))\right). \tag{11.20}$$

这一记号下，迭代十分方便。**译注：**原文把稀疏随机询问图直接称为正则图，需区分图系综。反双曲正切恒等式的 y/x 混用，以及式 (11.15)–(11.19) 中多出的右括号按可见原式保留，后面的紧凑 BP 式使用原文自己的完整配对括号。

11.2.2 群体动力学

可以证明，该算法完美求解自旋玻璃博弈。还可用群体动力学分析贝叶斯表现，定义

$$F_{\mathrm{BP}}(\{m^{k\to j}\}) = \tanh\left(\sum_{k\in\partial j\setminus i} \operatorname{atanh}(m^{k\to j}\tanh(\beta J_{kj}))\right). \tag{11.21}$$

消息的概率密度分布由以下方程的不动点给出：

$$\mathcal{P}(m^{\mathrm{cav}}) = \int dc\, P^{\mathrm{excess}}(c) \prod_{i=1}^{c} dm_i\, \mathcal{P}(m_i)\delta(m - F_{\mathrm{BP}}\{m\}). \tag{11.22}$$

译注：“完美求解”是原文措辞，不应理解为任意含噪 / 不连通图均可逐节点无误差恢复。群体方程把整数度写成积分，delta 中又用 m 而非 m^{cav}，且未显式列出对耦合 J 的抽样平均；均保留源式。

11.2.3 相变

相变为二阶，因此可用局域扰动确定位置。令 $m^{j\to i} = \varepsilon^{j\to i} S_j^*$，一阶有

$$\begin{aligned}\varepsilon^{j\to i} S_j^* &\approx \tanh\left(\sum_{k\in\partial j\setminus i} \varepsilon^{k\to j} S_k^* \tanh(\beta J_{kj})\right) \\ &\approx \sum_{k\in\partial j\setminus i} \varepsilon^{k\to j} S_k^* \tanh(\beta J_{kj}).\end{aligned} \tag{11.23}$$

等价地，若同质增长，

$$\varepsilon \approx \sum_{k\in\partial j\setminus i} \varepsilon S_k^* S_j^* \tanh(\beta J_{kj}). \tag{11.24}$$

平均而言，磁化在以下条件下增长：

$$1 = c\mathbb{E}[S_i^* S_j^* \tanh(\beta J_{ij})] = c(1-2p)\tanh\beta = c\tanh^2\beta. \tag{11.25}$$

因此转变发生于

$$\beta = \sqrt{\frac{1}{\operatorname{atanh}(2M/N)}} = \sqrt{\frac{1}{\operatorname{atanh} c}}. \tag{11.26}$$

译注：源阈值式 (11.26) 与上一判据不等价；正则图还应区分平均度与剩余度。原式保留，不替换为重新推导的阈值。

11.3 稠密图极限：TAP / AMP

现在研究稠密图，甚至可假定观测全部节点对；为使问题有意思，令说谎概率接近 $1/2$：

$$p_{\mathrm{Dense}} = \frac{e^{-\beta/\sqrt{N}}}{e^{-\beta/\sqrt{N}} + e^{\beta/\sqrt{N}}} = \frac{1}{1+e^{2\beta/\sqrt{N}}}. \tag{11.27}$$

该极限下，问题为

$$P_{\mathrm{post}}(S \mid J) = \frac{1}{Z} e^{(\beta/\sqrt{N})\sum_{i<j} J_{ij} S_i S_j}. \tag{11.28}$$

当然，可以写出相同 BP 算法：

$$m^{j\to i} = \tanh\left(\sum_{k\in\partial j\setminus i} \operatorname{atanh}\left(m^{k\to j}\tanh\left(\frac{\beta}{\sqrt{N}} J_{kj}\right)\right)\right). \tag{11.29}$$

转变发生于 $\beta = 1$，因为判据变为

$$1 = \frac{2N^2/2}{N}\tanh^2\left(\frac{\beta}{\sqrt{N}}\right) \approx \beta^2. \tag{11.30}$$

11.4 近似消息传递

这是研究问题的良好极限，但有一处不便：需要更新 N^2 条消息，实在太多！办法是对 BP 作 Taylor 展开。一阶 BP 迭代为

$$m_{t+1}^{j\to i} = \tanh\left(\sum_{k\in\partial j\setminus i} \operatorname{atanh}\left(m_t^{k\to j}\tanh\left(\frac{\beta}{\sqrt{N}}J_{kj}\right)\right)\right)$$
$$\approx \tanh\left(\frac{\beta}{\sqrt{N}}\sum_{k\in\partial j\setminus i} m_t^{k\to j}J_{kj}\right). \tag{11.31}$$

此时可将方程闭合到完整边缘，其定义为

$$m_{t+1}^{j} = \tanh\left(\frac{\beta}{\sqrt{N}}\sum_{k} m_t^{k\to j}J_{kj}\right). \tag{11.32}$$

事实上，

$$m_{t+1}^{j\to i} = \tanh\left(\frac{\beta}{\sqrt{N}}\sum_{k} m_t^{k\to j}J_{kj} - \frac{\beta}{\sqrt{N}}m_t^{i\to j}J_{ij}\right), \tag{11.33}$$
$$\approx \tanh\left(\frac{\beta}{\sqrt{N}}\sum_{k} m_t^{k\to j}J_{kj}\right)$$
$$- \frac{\beta}{\sqrt{N}}m_t^{i\to j}J_{ij}\tanh'\left(\frac{\beta}{\sqrt{N}}\sum_{k} m_t^{k\to j}J_{kj}\right), \tag{11.34}$$
$$\approx m_{t+1}^{j} - \frac{\beta}{\sqrt{N}}m_t^{i\to j}J_{ij}[1-(m_{t+1}^{j})^2], \tag{11.35}$$
$$\approx m_{t+1}^{j} - \frac{\beta}{\sqrt{N}}m_t^{i}J_{ij}[1-(m_{t+1}^{j})^2], \tag{11.36}$$
$$\tag{11.37}$$

其中保留了关于 N 的第一项修正。最后，结合两个方程

$$m_t^{k\to j} = m_t^k - \frac{\beta}{\sqrt{N}}m_{t-1}^{j}J_{jk}[1-(m_t^k)^2], \tag{11.38}$$
$$m_{t+1}^{j} = \tanh\left(\frac{\beta}{\sqrt{N}}\sum_{k} m_t^{k\to j}J_{kj}\right), \tag{11.39}$$

得到

$$m_{t+1}^{j} = \tanh\left\{\frac{\beta}{\sqrt{N}}\sum_{k} J_{kj}\left[m_t^k - \frac{\beta}{\sqrt{N}}m_{t-1}^{j}J_{jk}(1-(m_t^k)^2)\right]\right\}, \tag{11.40}$$
$$m_{t+1}^{j} = \tanh\left\{\frac{\beta}{\sqrt{N}}\sum_{k}\left[J_{kj}m_t^k - \frac{\beta}{\sqrt{N}}m_{t-1}^{j}(1-(m_t^k)^2)\right]\right\}, \tag{11.41}$$
$$m_{t+1}^{j} = \tanh\left\{\frac{\beta}{\sqrt{N}}\sum_{k} J_{jk}m_t^k - \beta^2 m_{t-1}^{j}\left(1-\sum_{k}\frac{(m_t^k)^2}{N}\right)\right\}. \tag{11.42}$$

方便地写为

$$\mathbf{h}_t = \frac{1}{\sqrt{N}}\mathbf{J}\mathbf{m}_t - \beta\mathbf{m}_{t-1}(1-\overline{m_t^2}), \tag{11.43}$$

$$\mathbf{m}_{t+1} = \tanh(\beta \mathbf{h}^t). \tag{11.44}$$

这就是 TAP 或 AMP 算法。第一式第二项称为 Onsager 项，它使结果与朴素平均场近似产生微妙差别！一般可写为

$$\mathbf{h}_t = \frac{1}{\sqrt{N}} \mathbf{J}\mathbf{m}_t - \mathbf{m}_{t-1} \overline{\partial_h \eta(\beta \mathbf{h}^{t-1})}, \tag{11.45}$$

$$\mathbf{m}_{t+1} = \eta(\beta \mathbf{h}^t). \tag{11.46}$$

写出算法如此方便简洁；事实上，这一形式正是 AMP 算法！**译注：** 源文编号 (11.37) 只有编号而无公式，译文保留空位，不补写内容。横线为原文的分量平均简记；t 的上下标及导数自变量约定依源式保留。

11.4.1 状态演化

回到迭代

$$m_{t+1}^{j\to i} = \tanh\left(\sum_{k\in \partial j \setminus i} \operatorname{atanh}\left(m_t^{k\to j} \tanh\left(\frac{\beta}{\sqrt{N}} J_{kj} \right) \right) \right). \tag{11.47}$$

不直接关注 m 的群体动力学，而将迭代分解为

$$m_{t+1}^{j\to i} = \tanh h_t^{j\to i}, \tag{11.48}$$

$$h_t^{j\to i} = \sum_{k\in \partial j \setminus i} \operatorname{atanh}\left(m_t^{k\to j} \tanh\left(\frac{\beta}{\sqrt{N}} J_{kj} \right) \right). \tag{11.49}$$

树上 $h_t^{j\to i}$ 的分布由不相关项的和组成，因此对大树、大连接度极限，预期可进一步简化。先在大连接度下改写为

$$m_{t+1}^{j\to i} = \tanh h_t^{j\to i}, \tag{11.50}$$

$$h_t^{j\to i} = \frac{\beta}{\sqrt{N}} \sum_k m_t^{k\to j} J_{kj}), \tag{11.51}$$

$$h_t^{j\to i} \sim \mathcal{N}(\overline{h}^t, \Delta h^t). \tag{11.52}$$

若 h 分布的均值和方差为 m, q，即可闭合方程：

$$h_t^{j\to i} S_i^* = S_i^* \frac{\beta}{\sqrt{N}} \sum_k \left[\delta(J = \mathrm{OK}) S_i^* S_k^* m_t^{k\to j} - \delta(J = \mathrm{lies}) S_i^* S_k^* m_t^{k\to j} \right], \tag{11.53}$$

$$= \frac{\beta}{\sqrt{N}} \sum_k \left[\delta(J = \mathrm{OK}) S_k^* m_t^{k\to j} - \delta(J = \mathrm{lies}) S_k^* m_t^{k\to j} \right]. \tag{11.54}$$

定义沿隐藏状态方向的 m 分布的均值与二阶矩：

$$q^t = \mathbb{E}[(m^{i\to j} S_i^*)^2], \tag{11.55}$$

$$m^t = \mathbb{E}[m^{i\to j} S_i^*]. \tag{11.56}$$

于是

$$\overline{h}^{\,t} = N\frac{\beta}{\sqrt{N}}(1-2p)m_t = N\frac{\beta}{\sqrt{N}}\tanh(\beta/\sqrt{N})m_t = \beta^2 m_t, \tag{11.57}$$

$$\Delta_t = \beta^2 q_t. \tag{11.58}$$

因此可写为

$$q^t = \mathbb{E}_z[\tanh(\beta^2 m_t + z\beta\sqrt{q_t})^2], \tag{11.59}$$

$$m^t = \mathbb{E}_z[\tanh(\beta^2 m_t + z\beta\sqrt{q_t})]. \tag{11.60}$$

这与用副本法可得到的结果相同。**译注：** 源式 (11.51) 多一个右括号；式 (11.53)、(11.54) 在求和末尾也各有一个未配对右括号，本译把两项差用方括号补配排版，属于译者解释性补配，原作者的分组意图未确认；根的 i/j 指标及 $\Delta h^t/\Delta^t$ 混用照录。最后两式左右都用同一时刻 t，未写成 $t+1$，不能在翻译中默默改成另一递推；关于高斯场和独立项的条件仍需按渐近设定核对。

11.5 从自旋玻璃博弈到秩一分解

上述形式在大连接度极限实际上很一般。假定问题为

$$\mathbf{Y} = \sqrt{\frac{1}{N}}\,\mathbf{x}^*(\mathbf{x}^*)^{\mathsf{T}} + \sqrt{\Delta}\,\mathbf{W}, \tag{11.61}$$

其中 $\mathbf{W}$ 是随机矩阵，$\mathbf{x}^*$ 从分布 P_0 抽取。若要解这一问题，只需写出 AMP 算法

$$\mathbf{h}_t = \frac{1}{\sqrt{N}}\mathbf{J}\mathbf{m}_t - \mathbf{m}_{t-1}\overline{\beta\eta'(\beta\mathbf{h}^{t-1})}, \tag{11.62}$$

$$\mathbf{m}_{t+1} = \eta(\beta\mathbf{h}^t), \tag{11.63}$$

但这次应采用不同的去噪器：

$$\eta_t(h) = \eta(A = \beta\overline{m_t^2}, B = \beta h) := \frac{\int dx\, P_X(x) x e^{-x^2A/2+xB}}{\int dx\, P_X(x) e^{-x^2A/2+xB}}. \tag{11.64}$$

再次得到状态演化：

$$m^t = \mathbb{E}_{z,x^*}[x^*\eta(\beta m^t, \beta m_t x^* + z)]. \tag{11.65}$$

译注： 源文从观测 $\mathbf{Y}$ 改用算法中的 $\mathbf{J}$，先验 P_0 改为 P_X，未在此给出 β 与 Δ 的映射；最后状态演化的噪声系数、去噪器两个参数及时间指标也需与前面约定核对。各式保持原样，不据此声称任意先验与噪声下算法均已被证明最优。

12 近似消息传递与状态演化

我希望有人收到我的，我希望有人收到我的漂流瓶中的讯息。

Sting，The Police，1979

12.1 对理想迭代的一厢情愿分析

考虑如下迭代：

$$h^{t+1} = Ax^t, \tag{12.1}$$

$$x^t = f_t(h^t), \tag{12.2}$$

其中两个向量均属于 $\mathbb{R}^N$，且 $A_{ij} = A_{ji}\,\mathcal{N}(0,1/N)$。设从 $t=0$ 的随机高斯向量 $h^{(0)}$ 开始，每个分量服从 $\mathcal{N}(0,q^0)$。h^t 的分量服从什么分布？很容易认为它们将一直保持高斯分布，但事实并非如此。考虑 $f_t(h^t)=h^t$ 的情形，有

$$h^{t=1} = Ah^{t=0}, \tag{12.3}$$

$$h^{t=2} = AAh^{t=0}. \tag{12.4}$$

中心极限定理使第一步 $h^{t=1}$ 呈高斯分布。然而，矩阵 AA 的非对角元虽然基本为高斯且彼此近乎不相关，对角元却很接近 1，因而 $AA \sim A' + 1$。于是依概率有

$$h^{t=2} = A'h^{t=0} + h^{t=0}. \tag{12.5}$$

这开始引入不同时刻之间的非平凡关联，因此改用算法

$$h^{t+1} = Ax^t - b_t x^{t-1}, \tag{12.6}$$

$$x^t = f_t(h^t), \tag{12.7}$$

其中所谓 Onsager 项为

$$b_t = \mathbb{E}[\operatorname{div} f_t(Z^t)]. \tag{12.8}$$

此时，迭代给出

$$h^{t=2} = \widetilde{A}h^{t=0} + h^{t=0} - h^{t=0} = \widetilde{A}h^{t=0}. \tag{12.9}$$

Onsager 项使最初的愿望得以实现。事实上，可对修正后的迭代建立如下定理，这里仅作非正式陈述。

定理 17 (Bolthausen 11，Bayati–Montanari '11)**.** *对任意有限时刻，当 $N \to \infty$ 时，有*

$$h^t \sim \mathcal{N}(0, \mathbf{1}q^t), \tag{12.10}$$

$$q^{t+1} = \frac{1}{N}\sum_i (x_i^{t+1})^2 = \mathbb{E}[f_t^2(Z \sim \mathcal{N}(0,q^t))]. \tag{12.11}$$

译注：矩阵分布的原文记法未显示分布符号；div 的归一化、初值与矩阵的独立性及函数正则性等，须由定理的完整假设规定。这里保留原作者非正式陈述，时标及 **1** 记号不作统一。

12.2 近似消息传递及其状态演化

本节讨论这一结论如何证明。我们遵循 Bolthausen（2009，2014），考虑采用对称矩阵的迭代。

12.2.1 对称 AMP

考虑对称 AMP，沿用矩阵、函数和输入等方面的假设：

$$x^{t+1} = Am^t - b_t m^{t-1}, \tag{12.12}$$

$$m^t = f_t(x^t), \tag{12.13}$$

从 x^0 初始化，并取

$$b_t = \mathbb{E}[\operatorname{div} f_t(Z^t)], \tag{12.14}$$

其中 $Z^t \sim \mathcal{N}(0, \kappa_{t,t} I_n)$。我们声称，迭代中的所有 x^s 都表现为高斯变量，$x^t \sim \mathcal{N}(0, \kappa_t)$，且 $X \sim \mathcal{N}(0, \kappa_{t,s})$。此外，

$$\kappa_{s,t} = \frac{1}{N} m^{s-1} m^{t-1} =: q^{s-1,t-1}. \tag{12.15}$$

若每一步都使用一个新的矩阵 A，这正是没有 Onsager 项时的行为。Onsager 修正使同一个 A 在各步保持不变时，这一结论仍成立。

12.2.2 对线性观测取条件

定义 σ 代数 $\mathcal{S}_t = \sigma(x^1, x^2, \ldots, x^t)$。由于 m^t, m^{t-1} 是 $\mathcal{S}_t$ 可测的，有

$$x^{t+1} \mid \mathcal{S}_t = (A \mid \mathcal{S}_t) m^t - b_t m^{t-1}. \tag{12.16}$$

简单递推可知，对 $\mathcal{S}_t$ 取条件，等价于对 $Am^0, Am^1, \ldots, Am^{t-1}$ 所生成的高斯空间取条件。它是 A 的矩阵元所生成高斯空间的子空间。对高斯空间的子空间取条件相当于做正交投影，因此对于 GOE(n)，有

$$A \mid \mathcal{S}_t = \mathbb{E}[A \mid \mathcal{S}_t] + \mathcal{P}_t(A), \tag{12.17}$$

$$= A - P^{\perp}_{M_{t-1}} A P^{\perp}_{M_{t-1}} + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}}, \tag{12.18}$$

其中 $M_{t-1} = [m^0 | \cdots | m^{t-1}]$，$\widetilde{A}$ 为 A 的独立副本。应用于对称 AMP，得到

$$x^{t+1} \mid \mathcal{S}_t = \big(A - P^{\perp}_{M_{t-1}} A P^{\perp}_{M_{t-1}} + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}}\big) m^t - b_t m^{t-1}, \tag{12.19}$$

$$= \big(A - (\mathrm{Id} - P_{M_{t-1}}) A (\mathrm{Id} - P_{M_{t-1}})\big) m^t + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t - b_t m^{t-1}, \tag{12.20}$$

$$= \big(A P_{M_{t-1}} + P_{M_{t-1}} A P^T_{M_{t-1}}\big) m^t + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t - b_t m^{t-1}, \tag{12.21}$$

$$= A P_{M_{t-1}} m^t + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t + P_{M_{t-1}} A m^t_{\perp} - b_t m^{t-1}. \tag{12.22}$$

假设 M_{t-1} 满秩，将 m^t 在 M_{t-1} 列空间上的投影系数唯一地记为 α_t，有

$$x^{t+1} \mid \mathcal{S}_t = A M_{t-1} \alpha_t + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t + P_{M_{t-1}} A m^t_{\perp} - b_t m^{t-1}. \tag{12.23}$$

根据对称 AMP 的定义，$AM_{t-1} = X_{t-1} + [0|M_{t-2}]B_t$，其中 $X_{t-1} = [x^1|\cdots|x^t]$，$B_t$ 为 Onsager 系数组成的对角矩阵。于是

$$\begin{aligned} x^{t+1} \mid \mathcal{S}_t &= (X_{t-1} + [0|M_{t-2}]B_t)\alpha_t \\ &\quad + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t + P_{M_{t-1}} A m^t_{\perp} - b_t m^{t-1}, \qquad (12.24) \\ &= \underbrace{X_{t-1}\alpha_t + P^{\perp}_{M_{t-1}} \widetilde{A} P^{\perp}_{M_{t-1}} m^t}_{\text{第一部分}} \\ &\quad + \underbrace{[0|M_{t-2}]B_t\alpha_t + P_{M_{t-1}} A m^t_{\perp} - b_t m^{t-1}}_{\text{第二部分}}. \qquad (12.25) \end{aligned}$$

第一部分显然是以往各项与一个新增高斯项的线性组合；新增项是独立 GOE 矩阵与固定的 M 相乘。第二部分在高维极限下通过等距性质与 Stein 引理抵消，也就是 Onsager 的 “魔法”。递推便直观地给出每次迭代内及不同迭代间的高斯等效模型。

现在说明第二部分如何抵消。关注

$$\begin{aligned} \mathcal{A} &= P_{M_{t-1}} A m^t_{\perp}, \qquad (12.26) \\ &= M_{t-1}(M^T_{t-1}M_{t-1})^{-1} M^T_{t-1} A m^t_{\perp}, \qquad (12.27) \\ &= M_{t-1}(M^T_{t-1}M_{t-1})^{-1} (AM_{t-1})^T m^t_{\perp}. \qquad (12.28) \end{aligned}$$

而 $(AM_{t-1})^T = (X_{t-1} - [0|M_{t-2}]B_t)^T$，所以

$$(AM_{t-1})^T m^t_{\perp} = (X^T_{t-1} - B^T_t [0|M_{t-2}]^T) m^t_{\perp} = X^T_{t-1} m^t_{\perp}. \qquad (12.29)$$

于是

$$\begin{aligned} \mathcal{A} &= M_{t-1}(M^T_{t-1}M_{t-1})^{-1} X^T_{t-1} m^t_{\perp}, \qquad (12.30) \\ &= M_{t-1}(M^T_{t-1}M_{t-1})^{-1} X^T_{t-1}(m^t - m^t_{\parallel}), \qquad (12.31) \\ &= M_{t-1}(M^T_{t-1}M_{t-1})^{-1} X^T_{t-1}(f^t(x^t) - M^{t-1}\alpha^t). \qquad (12.32) \end{aligned}$$

这里必须小心各项的尺度。所得向量的每个分量应为一阶量。为突出这一点，可写为

$$\mathcal{A} = \left(M_{t-1}(M^T_{t-1}M_{t-1})^{-1} N\right) \left(\frac{1}{N} X^T_{t-1}(f^t(x^t) - M^{t-1}\alpha^t)\right). \qquad (12.33)$$

现在，一个矩阵元为 $O(1)$ 的矩阵乘以分量为 $O(1)$ 的向量，仍给出 $O(1)$ 的量，因为求和只涉及有限的 t 个取值。考察第二个括号里的两项：

$$\mathcal{B} = \frac{1}{N} X^T_{t-1}(f^t(x^t) - M^{t-1}\alpha^t) = \mathcal{C} + \mathcal{D}. \qquad (12.34)$$

利用 Stein 引理可化简。具体地，

$$\begin{aligned} \mathcal{C} &= \frac{1}{N} X^T_{t-1} f^t(x^t), \qquad (12.35) \\ &= \begin{bmatrix} N^{-1}\sum_i x^{(1)}_i f(x^{(t)}_i) \\ N^{-1}\sum_i x^{(2)}_i f(x^{(t)}_i) \\ \vdots \\ N^{-1}\sum_i x^{(t)}_i f(x^{(t)}_i) \end{bmatrix}, \qquad (12.36) \end{aligned}$$

$$=_{N\to\infty} \begin{bmatrix} \mathbb{E}[z^1 f(z^{(t)})] \\ \mathbb{E}[z^2 f(z^{(t)})] \\ \vdots \\ \mathbb{E}[z^t f(z^{(t)})] \end{bmatrix}. \tag{12.37}$$

(12.38)

其中使用了递推假设。现在应用 Stein 引理[8]，得到

$$\mathcal{C} = \begin{bmatrix} \kappa_{1,t}\mathbb{E}[f'(z^{(t)})] \\ \kappa_{2,t}\mathbb{E}[f'(z^{(t)})] \\ \vdots \\ \kappa_{t,t}\mathbb{E}[f'(z^{(t)})] \end{bmatrix} = b_t \begin{bmatrix} \kappa_{1,t} \\ \kappa_{2,t} \\ \vdots \\ \kappa_{t,t} \end{bmatrix}. \tag{12.39}$$

又有

$$\kappa_{s,t} = \frac{1}{N} m^{s-1} m^{t-1}, \tag{12.40}$$

因此

$$\mathcal{C} = \frac{1}{N} b_t \begin{bmatrix} (m^0)^T m^{t-1} \\ (m^1)^T m^{t-1} \\ \vdots \\ (m^{t-1})^T m^{t-1} \end{bmatrix} = \frac{1}{N} b_t M_{t-1}^T m^{t-1}. \tag{12.41}$$

类似地处理 $\mathcal{D}$，得到

$$\mathcal{D} = \frac{1}{N} M_{t-1}^T [0|M_{t-2}] B_t \alpha_t. \tag{12.42}$$

最终，

$$\mathcal{A} = \big(M_{t-1}(M_{t-1}^T M_{t-1})^{-1} N\big) \left[\frac{1}{N} X_{t-1}^T (f^t(x^t) - M^{t-1}\alpha^t)\right], \tag{12.43}$$

$$= M_{t-1}(M_{t-1}^T M_{t-1})^{-1} M_{t-1}^T \big(b_t m^{t-1} - [0|M_{t-2}] B_t \alpha_t\big), \tag{12.44}$$

$$= P_{M_{t-1}} \big(b_t m^{t-1} - [0|M_{t-2}] B_t \alpha_t\big). \tag{12.45}$$

这正是消去第二部分所需的项！至此，原文认为上述结论已经证明。**译注：** 式 (12.21) 的 P^T、AM_{t-1} 在前后出现的加减号差异、式 (12.32)、(12.33)、(12.34)、(12.43) 中的 $M^{t-1}\alpha^t$ 上标记法以及式 (12.33) 的乘法 N，以及式 (12.42) 的正号，均按原式保留。式 (12.38) 在原文中为空编号。式 (12.15)、(12.40) 未显式写内积转置。以上仍是原作者的递推证明梗概，不代表这些记号和渐近步骤已获严格认证。

此外，现在可以写出 κ_t 或等价的 q_t 的演化，这就称为状态演化：

$$q_t = \frac{1}{N} m^t m^t = \mathbb{E}[(f_t(\sqrt{\kappa_t} Z))^2] = \mathbb{E}[(f_t(\sqrt{q_{t-1}} Z))^2]. \tag{12.46}$$

[8]Stein 引理：设 X 为正态随机变量，方差为 κ，则 $\mathbb{E}[g(X)X] = \kappa\mathbb{E}[g'(X)]$。一般地，若 X, Y 联合正态，则 $\mathrm{Cov}(g(X), Y) = \mathrm{Cov}(X, Y)\mathbb{E}[g'(X)]$。原脚注在单变量情形的均值说明处缺字；所写未中心化等式还需要零均值。

这一结论的普适性很有意思。事实上，f 甚至不必可分离，原文还说不必“定义良好”，参见 Berthier 等（2020）。这使我们能把此类迭代用于神经网络（原引文带未解析的“?”：Gerbelot 与 Berthier，2021）以及信号处理的黑箱函数（原引文为“?”）。**译注：**该推广仍需相应定理的具体假设，不能将这句话理解为对任意未定义函数均有结论。

12.2.3 AMP 的收敛性

一个关键问题是 x^t（或 m^t）是否收敛。可考察

$$\frac{1}{N}\|m^{t+1}-m^t\|_2^2 = q^{t+1}+q^t-2q^{t,t+1}. \tag{12.47}$$

假设 q 已收敛（但 x 未必收敛!），AMP 轨道满足 $q^{t+1}=q^t=q^*$，问题便归结为 $q^{t,t+1}$ 是否收敛到 q^*。可以写为

$$C^{t+1}=q_{t+1,t}=\frac{1}{N}m^{t+1}m^t=\mathbb{E}[f_t(X^{t+1})f_t(X^t)]. \tag{12.48}$$

利用高斯等效性，将两个 X 换成相关高斯变量：

$$X^t=\sqrt{\kappa_t-\kappa_{t,s}}Z'+\sqrt{\kappa_{t,s}}Z, \tag{12.49}$$

$$X^s=\sqrt{\kappa_s-\kappa_{t,s}}Z''+\sqrt{\kappa_{t,s}}Z. \tag{12.50}$$

在 $\kappa_s=\kappa_t=q^*$ 的不动点上，

$$\begin{aligned} C^{t+1} &= \mathbb{E}\Big[f_t\big(\sqrt{\kappa_{t+1}-\kappa_{t+1,t}}Z'+\sqrt{\kappa_{t+1,t}}Z\big) \\ &\qquad \cdot f_t\big(\sqrt{\kappa_t-\kappa_{t+1,t}}Z''+\sqrt{\kappa_{t+1,t}}Z\big)\Big], && (12.51)\\ &= \mathbb{E}\Big[f_t\big(\sqrt{q^*-C^t}Z'+\sqrt{C^t}Z\big)f_t\big(\sqrt{q^*-C^t}Z''+\sqrt{C^t}Z\big)\Big], && (12.52)\\ &= g(C^t). && (12.53) \end{aligned}$$

于是问题是：定义于 $[0,q^*]$ 的映射 g 的不动点迭代是否收敛？原文根据不动点定理，要求映射具有压缩性，即任意 x,y 满足

$$\|g(x)-g(y)\|\le|x-y|. \tag{12.54}$$

也就是说，要求 g 为 1-Lipschitz。可证明 g 的一阶、二阶导数都为正（求导并使用 Stein 引理），因而导数在 q^* 处最大。简单计算得到判据

$$\mathbb{E}\big[(f_t'(\sqrt{q^*}Z))^2\big]\le 1. \tag{12.55}$$

译注：原文用非扩张条件 ≤ 1 代替严格压缩条件；临界等号一般不能单凭压缩映射定理保证收敛。相关高斯的平方根表示也要求相应协方差范围，未据此补造一般情形的证明。

12.2.4 第一个应用：TAP 方程

考虑函数

$$f_t(x)=\tanh(\beta x+h). \tag{12.56}$$

此时，AMP 简化为

$$b_t = \beta(1 - \mathbb{E}[\tanh(\beta x^t + h)^2]) = \beta(1 - q^t), \tag{12.57}$$

$$x^{t+1} = Am^t - \beta(1 - q^t)m^{t-1}, \tag{12.58}$$

$$m^{t+1} = \tanh(\beta x^{t+1} + \beta h), \tag{12.59}$$

$$m^{t+1} = \tanh\big(\beta(Am^t - \beta(1 - q^t)m^{t-1}) + \beta h\big). \tag{12.60}$$

这就是 SK 模型的 TAP 方程（Thouless 等，1977），q 满足 Parisi 的副本对称方程：

$$q_t = \mathbb{E}[(\tanh(\beta\sqrt{q_{t-1}}Z + \beta h))^2]. \tag{12.61}$$

此外，当

$$\mathbb{E}\big[(\tanh'(\beta\sqrt{q^*}Z + \beta h))^2\big] \le 1 \tag{12.62}$$

时也可收敛；原文称其恰为 Almeida–Thouless 判据，这是 Bolthausen（2014）原论文的主要结果。**译注：**式 (12.56) 与后文场的 $h/\beta h$ 约定不一致；式 (12.62) 的导数自变量和链式法则中的 β 因子，仍按源式保留，不能据此无条件认证临界收敛。

12.2.5 再看 Parisi 方程：近似调查传播

既然 SK 模型的 Parisi RS 方程出现了，便可问：RSB 方程是否也是某种迭代的状态演化？答案是肯定的，如文献 “?” 所示（原文引文未解析）。一般地定义

$$f_t(x) = \frac{\mathbb{E}_V\big[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m \tanh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)\big]}{\mathbb{E}_V[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m]}, \tag{12.63}$$

$$q_1^{t+1} = \mathbb{E}_U\left[\frac{\mathbb{E}_V\big[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m \tanh^2(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)\big]}{\mathbb{E}_V[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m]}\right], \tag{12.64}$$

$$q_0^{t+1} = \mathbb{E}_U\left[\left(\frac{\mathbb{E}_V\big[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m \tanh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)\big]}{\mathbb{E}_V[\cosh(\beta x + \beta\sqrt{q_1^t - q_0^t}V + \beta h)^m]}\right)^2\right]. \tag{12.65}$$

由此得到的 AMP 迭代，其状态演化遵循 Parisi 的 1RSB 方程。特别地，原文说 f_t 的范数为 q_0。因此，Parisi 方程可以解释为描述某个迭代算法随时间演化的方式。**译注：**上式虽对 U 取期望，被积表达式仍用 x，原文没有在此明确 x 与 U 的关系；“范数” 与平方范数的约定也未说明，均未代为补定。

12.3 应用

12.3.1 Wigner 尖峰模型

从 Wigner 尖峰模型开始，考虑递推

$$x^{t+1} = \left(A + \frac{\sqrt{\lambda}}{N}x_* x_*^T\right)m^t - b_t m^{t-1} = Ym^t - b_t m^{t-1}, \tag{12.66}$$

$$m^t = f_t(x^t). \tag{12.67}$$

如何处理？做变量替换，直接写成

$$x^{t+1} = Am^t - b_t m^{t-1} + \sqrt{\lambda} x_* q_0^t, \tag{12.68}$$

$$\widetilde{x}^{t+1} = Am^t - b_t m^{t-1}, \tag{12.69}$$

$$q_0^t = \frac{1}{N} x_*^T m^t. \tag{12.70}$$

定义 $\widetilde{f}_t(x) = f_t(x + x_0 q_0^t)$，则可写为

$$\widetilde{x}^{t+1} = Am^t - b_t m^{t-1}, \tag{12.71}$$

$$m^t = \widetilde{f}_t(\widetilde{x}^t). \tag{12.72}$$

因此可以对带波浪号的变量使用状态演化，再次得到

$$q_t = \frac{1}{N} m^t m^t = \mathbb{E}[(\widetilde{f}_t(\sqrt{q_{t-1}} Z))^2], \tag{12.73}$$

$$= \mathbb{E}[(f_t(\sqrt{q_{t-1}} Z + \sqrt{\lambda} q_0^{t-1} X^*))^2]. \tag{12.74}$$

根据 q_0^t 的定义，联合状态演化为

$$q^t = \mathbb{E}[(f_t(\sqrt{q_{t-1}} Z + \sqrt{\lambda} q_0^{t-1} X^*))^2], \tag{12.75}$$

$$q_0^t = \mathbb{E}[f_t(\sqrt{q_{t-1}} Z + \sqrt{\lambda} q_0^{t-1} X^*) X_*]. \tag{12.76}$$

看一个具体例子：**Rademacher 尖峰模型**。给定

$$Y = \frac{1}{\sqrt{N}} \left(W + \sqrt{\frac{\lambda}{N}} x_* x_*^T \right), \qquad x_i^* = \pm 1,$$

能恢复该向量吗？可使用 AMP 算法

$$x^{t+1} = Y m^t - b_t m^{t-1}, \tag{12.77}$$

$$m^t = f_t(x^t), \tag{12.78}$$

并取二元去噪函数 $f_t(x) = \tanh(\sqrt{\beta} x)$。这是 TAP 方程的特例，常称为植入的 SK 模型。此时状态演化为

$$q^t = \mathbb{E}[(\tanh(\beta \sqrt{q_{t-1}} Z + \beta \sqrt{\lambda} q_0^{t-1} X^*))^2], \tag{12.79}$$

$$q_0^t = \mathbb{E}[\tanh(\beta \sqrt{q_{t-1}} Z + \beta \sqrt{\lambda} q_0^{t-1} X^*) X_*]. \tag{12.80}$$

这就是带铁磁偏置的 SK 模型的方程；该语境下 λ 常记为 J_0。**译注：** $\widetilde{f}_t$ 定义中的 x_0、后文的 $x_*/X^*/X_*$ 以及时间指标均保留原记法。二元去噪函数的 $\sqrt{\beta}$ 与后续状态演化的 β 不一致，未自行统一。

12.3.2 贝叶斯去噪入门

为什么使用双曲正切？这与统计学的贝叶斯方法有关。已知观测满足

$$X = q_0^{t-1}\sqrt{\lambda}X_* + \sqrt{q^{t-1}}Z.$$

X 只是叠加了高斯噪声的 X_0，如何作出最佳估计？

一般而言，按最小均方误差（MMSE）衡量，贝叶斯方法的“最佳”估计是后验均值。证明很容易：设可观测的 Y 是 X_* 的受污染版本，则对所有估计量，有

$$\mathrm{MMSE} = \mathbb{E}_{X_*,Y}[(\widehat{X}(Y) - X_*)^2] = \mathbb{E}_Y[\mathbb{E}_{X_*|Y}[(\widehat{X}(Y) - X_*)^2]]. \tag{12.81}$$

将其最小化！给定 Y 后，$\widehat{X}$ 只是一个数，对其求导可知，对每个 Y 应选择

$$\widehat{\ }(X) = \mathbb{E}_{X_*|Y}X^* = \int P(X \mid Y)X. \tag{12.82}$$

这就是贝叶斯最优估计。在本问题中，给定观测 $X = q_0^{t-1}\sqrt{\lambda}X_* + \sqrt{q^{t-1}}Z$，有

$$P(X^* \mid X) \propto P^{\mathrm{prior}}(X)P^{X|X^*}(X) \propto P^{\mathrm{prior}}(X)\exp\left[-\frac{(X - \sqrt{\lambda}q_0^{t+1}X^*)^2}{2q^{t-1}}\right], \tag{12.83}$$

$$\mathbb{E}[X^* \mid X] = \frac{\int dx\, xP^{\mathrm{prior}}(x)\exp[-(X - \sqrt{\lambda}q_0^{t+1}x)^2/(2q^{t-1})]}{\int dx\, P^{\mathrm{prior}}(x)\exp[-(X - \sqrt{\lambda}q_0^{t+1}x)^2/(2q^{t-1})]}. \tag{12.84}$$

这称为最优贝叶斯高斯去噪函数。**译注：**式 (12.81) 对任意估计量给出风险，只有取最小值后才是 MMSE。式 (12.82) 原左端只有帽号及 (X)，原积分未给微分；式 (12.83) 的先验自变量以及两式的 $t+1$ 均照录，不以熟知公式静默修正。

利用所谓 Nishimori 性质还可进一步简化。

定理 18 (Nishimori 恒等式)**.** *设 $X^{(1)},\dots,X^{(k)}$ 是给定 Y 后从分布 $P(X = \cdot \mid Y)$ 独立同分布抽取的 k 个样本。以 $\langle\cdot\rangle$ 表示关于 $P(X = \cdot \mid Y)$ 的“Boltzmann”平均，$\mathbb{E}[\cdot]$ 表示关于 (X^*, Y) 的“无序”平均。则对任意连续有界函数 f，可将一个副本替换为 X^*：*

$$\mathbb{E}[\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^{(k)})\rangle_k] = \mathbb{E}[\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^*)\rangle_{k-1}]. \tag{12.85}$$

证明. 由 Bayes 定理，以及 x^* 和任一副本 $X^{(k)}$ 给定 Y 后均服从后验分布，即得结论。对任意函数 g，将 k 个副本的 Boltzmann 平均明确写为

$$\langle g(X^{(1)},\dots,X^{(k)})\rangle_k := \int \prod_{i=1}^{k} dx_i\, P(x_i \mid Y)g(X^{(1)},\dots,X^{(k)}). \tag{12.86}$$

从右端出发，有

$$\begin{aligned}
&\mathbb{E}_{Y,X^*}[\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^*)\rangle_{k-1}] \\
&= \int dx^*dy\, P(x^* \mid Y)P(Y)\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^*)\rangle_{k-1} \\
&= \mathbb{E}_Y \int dx^k P(x^k \mid y)\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^k)\rangle_{k-1} \\
&= \mathbb{E}_Y[\langle f(Y, X^{(1)},\dots,X^{(k-1)},X^{(k)})\rangle_k].
\end{aligned}$$

□

此后省略 Boltzmann 平均的下标 k。

二元先验确实给出 $f^{(t)}=\tanh(\sqrt{\lambda}X)$，因为只有一个因子 $e^{x\sqrt{\lambda}q/q\,x}$（原文此括号未闭合）。据作者所知，这是多项式时间内最好的算法！

稀疏情形？困难相：没有已知算法！**译注：**最后两句保留原文的简略提纲和“据作者所知”的范围；不是一般计算复杂性下界。指数中两个 x 及未闭合括号按原可见文本记录。

12.3.3 Wishart 尖峰模型

给定两个向量 $u_*\in\mathbb{R}^n$、$v_*\in\mathbb{R}^m$，观测 $n\times m$ 矩阵（$\alpha=m/n$）

$$W=\sqrt{\frac{\lambda}{n}}u_*v_*^T+\xi. \tag{12.87}$$

AMP 算法（原引文为未解析的“?”）如下。这里利用方差可预先计算，将其隐含于每个时刻 t 所定义的函数 f 中：

$$u^{t+1}=\frac{1}{\sqrt{n}}Wg_v^t(v^t)-\alpha\langle g_v^{t\prime}(v)\rangle g_u^{t-1}(u^{t-1}), \tag{12.88}$$

$$v^{t+1}=\frac{1}{\sqrt{n}}Wg_u^t(u^t)-\langle g_u^{t\prime}(u^t)\rangle g_v^{t-1}(v^{t-1}). \tag{12.89}$$

可将这些方程方便地改写为适合严格分析的新形式。定义 $(n+m)\times 2$ 矩阵 X：

$$x=\begin{pmatrix}u & 0\\ 0 & v\end{pmatrix}, \tag{12.90}$$

以及相互作用矩阵

$$Y=\sqrt{\frac{\lambda}{n}}x_*x_*^T+Z=\sqrt{\frac{\lambda}{n}}\begin{pmatrix}u_*u_*^T & u_*v_*^T\\ (u_*v_*^T)^T & v_*v_*^T\end{pmatrix}+\begin{pmatrix}\xi_{\mathrm{up}} & \xi\\ \xi^T & \xi_{\mathrm{low}}\end{pmatrix}. \tag{12.91}$$

对每个时刻 t，逐行定义 $f^t:\mathbb{R}^{(m+n)\times 2}\to\mathbb{R}^{(m+n)\times 2}$（使用矩阵式记号）：

$$f_i=[0\quad g_u^t(x[i,1])], \qquad i=1,\dots,n, \tag{12.92}$$

$$f_i=[g_v^t(x[i,2])\quad 0], \qquad i=n+1,\dots,m+n, \tag{12.93}$$

$$ \tag{12.94}$$

则如下 AMP 递推与式 (12.88)、(12.89) 等价：

$$x^{t+1}=\frac{Y}{\sqrt{n}}f^t(x^t)-\frac{1}{n}\langle f^{t\prime}(x^t)\rangle f^{t-1}(X^{t-1}), \tag{12.95}$$

$$=\frac{Y}{\sqrt{n}}f^t(x^t)-b_tf^{t-1}(x^{t-1}). \tag{12.96}$$

其中将 Onsager 项统一记为 b_t。因此可直接从 Wigner 模型得到式 (12.88)、(12.89) 的状态演化：

$$q_u^t=\mathbb{E}[(g_u^t(\sqrt{\alpha q_v^{t-1}}Z+\alpha\sqrt{\lambda}q_v^{0\,t-1}V^*))^2], \tag{12.97}$$

$$q_u^{0\,t}=\mathbb{E}[(g_u^t(\sqrt{\alpha q_v^{t-1}}Z+\alpha\sqrt{\lambda}q_v^{0\,t-1})V^*)U_*], \tag{12.98}$$

$$q_v^t=\mathbb{E}[(g_v^t(\sqrt{q_u^{t-1}}Z+\sqrt{\lambda}q_u^{0\,t-1}U^*))^2], \tag{12.99}$$

$$q_v^{0\,t} = \mathbb{E}[g_v^t(\sqrt{q_u^{t-1}}Z + \sqrt{\lambda}q_u^{0\,t-1}U^*)V_*]. \tag{12.100}$$

它还有很多应用，包括尖峰模型去噪、高斯混合分析和 Hopfield 模型等。

若 $r > 4 + 2\sqrt{\alpha}$，信息论最优表现的阈值与已知算法成功的阈值之间存在间隔。**译注：**源式 (12.89) 未在 W 上写转置；块矩阵的定义与乘积、式 (12.98) 根号内的 q_v 及位于 g_u^t 函数外的 V^*（与前后式的对应关系存在疑点）、X/x 及指标位置均保留。式 (12.94) 原为空编号。最后一句没有在此交代 r 的定义和具体模型假设，不能脱离该范围应用。

12.4 从 AMP 到副本预测的证明：贝叶斯情形

从贝叶斯情形开始。设数据是按下式生成的 $n \times n$ 对称矩阵 Y：

$$Y = \sqrt{\frac{\lambda}{N}} \underbrace{x^* x^{*T}}_{N\times N \text{ 秩一矩阵}} + \underbrace{\xi}_{\text{对称的独立同分布噪声}},$$

其中 $x^* \in \mathbb{R}^N$，$x_i^* \overset{\text{iid}}{\sim} P_X(x)$，$\xi_{ij} = \xi_{ji} \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$ $(i \le j)$。统计学称之为 Wigner 尖峰模型：Y 是 Wigner 矩阵（矩阵元随机取自高斯分布的对称随机矩阵）加上一个 “尖峰”，即秩一矩阵 $x^* x^{*T}$。

下面映射到统计物理表述。对尖峰 Wigner 模型，使用 Bayes 公式得到

$$\begin{aligned}
P(x \mid Y) &= \frac{P(Y \mid x)P(x)}{P(Y)} \\
&\propto \left[\prod_i P_X(x_i)\right]\left[\prod_{i\le j} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(y_{ij} - \sqrt{\lambda/N}x_i x_j)^2}\right] \\
&\propto \left[\prod_i P_X(x_i)\right] \exp\left(\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2 x_j^2 + \sqrt{\frac{\lambda}{N}} y_{ij} x_i x_j\right]\right), \\
\Rightarrow \quad P(x \mid Y) &= \frac{1}{Z(Y)}\left[\prod_i P_X(x_i)\right] \exp\left(\sum_{i\le j}\left[-\frac{\lambda}{2N}x_i^2 x_j^2 + \sqrt{\frac{\lambda}{N}} y_{ij} x_i x_j\right]\right), \\
\widehat{x}_{\text{MSE}}(Y) &= \begin{bmatrix} \widehat{x}_{\text{MSE},1}(Y) \\ \vdots \\ \widehat{x}_{\text{MSE},N}(Y) \end{bmatrix}, \qquad \widehat{x}_{\text{MSE},i}(Y) = \langle x_i \rangle_Y = \int dx\, P(x \mid Y) x_i.
\end{aligned}$$

有趣的是，配分函数 $Z(Y)$ 等于如下比值：

$$Z(Y) = \frac{P(Y)}{e^{-\sum_{ij} y_{ij}^2/2}/(\sqrt{2\pi})^{N^2}}. \tag{12.101}$$

这就是所考虑模型生成数据的概率，与纯随机问题偶然生成数据的概率之间的似然比。

采用信息论记号、改算互信息会更方便。定义

$$I(X,Y) = \mathbb{E}_{X,Y} \log \frac{P(X,Y)}{P(X),P(Y)} = H(X) - H(X \mid Y) = H(Y) - H(Y \mid X). \tag{12.102}$$

本模型中，自由能与互信息之间的关系很容易计算：

$$\frac{I(X,Y)}{N} = f + \frac{\lambda(\mathbb{E}[X^2])^2}{4}. \tag{12.103}$$

既然互信息只是自由能，为什么用它？它有如下良好性质。

- 互信息随 λ 单调变化，从 0 变到 $H(X)$。前者直接来自定义，因为此时联合分布因子化；后者来自完美恢复 X 时 $H(Y \mid X) = 0$（原文如此）。
- 记矩阵 $M = X^*X$。用贝叶斯方法容易证明，由 Y 重构 M 所能达到的最佳误差由互信息的导数给出。这就是 I–MMSE 定理：

$$\text{M-MMSE} = \frac{1}{4}\frac{\partial I(\lambda)}{\partial \lambda}. \tag{12.104}$$

此外，该模型类似 SK 问题，$\sqrt{\lambda}$ 扮演逆温度的角色，文献中常称此为 Nishimori 条件。这是非常特殊的条件：施加该条件可证明 $q = m$!

通过副本法，可以经过一番计算导出自由能（此处 $q = m$）：

$$f(m) \approx \frac{\lambda m^2}{4} - \mathbb{E}_{x^*,z} \log \int dx_0 P(x_0) e^{-x_0^2 \lambda m/2 + \lambda x_0 x_0^* m + x_0 x_0^* \sqrt{\lambda m} z}. \tag{12.105}$$

还有一个有趣的恒等式：$df_{\text{rs}}/d\lambda = 4m^2/4$。因此，互信息的副本预测为

$$f_{\text{rs}} + \lambda\rho^2/4. \tag{12.106}$$

这很有意思，能证明吗？注意 AMP 不可能优于 MMSE。取估计量

$$\text{AMP-M} = m_i m_j. \tag{12.107}$$

它的误差容易计算：

$$\text{AMP-MSE} = \frac{1}{N^2}\sum_i (f_t(X_i) f_t(X_j) - X_i^* X_j^*). \tag{12.108}$$

取期望后就是

$$\text{AMP-MSE} = \rho^2 - m^2. \tag{12.109}$$

这一误差当然大于等于贝叶斯误差，所以

$$\text{AMP-MSE}(\lambda) > \text{MMSE}(\lambda), \tag{12.110}$$

$$\int d\lambda \frac{1}{4}\text{AMP-MSE}(\lambda) > \int \frac{1}{4}\text{MMSE}(\lambda) = I(\infty) - I(0) = H(X). \tag{12.111}$$

副本对称自由能的导数恰好给出 AMP–MSE！事实上，副本互信息的导数为

$$-\frac{1}{4}m^2 + \frac{1}{4}\rho^2 + \partial_\lambda T. \tag{12.112}$$

自由能的导数给出正确的项，最终确实得到 MSE。设可以无间断地积分，即 m 连续，则

$$\begin{aligned} I_{\text{replica}}(\infty) - I_{\text{replica}}(0) &= \int d\lambda \frac{1}{4}\text{AMP-MSE}(\lambda) \\ &> \int \frac{1}{4}\text{MMSE}(\lambda) = I(\infty) - I(0) = H(X). \end{aligned} \tag{12.113}$$

定义 $E = \rho - m$ 和 $\Sigma = 1/(\lambda m)$，则

$$I_{\text{replica}}(\lambda) = \frac{\lambda(\rho^2 + m^2)}{4} - \mathbb{E}_{x^*,z} \log \int dx_0 P(x_0) e^{-x_0^2 \lambda m/2 + \lambda x_0 x_0^* m + x_0 x_0^* \sqrt{\lambda m} z}$$

$$= I(X; X + \Sigma Z) + \frac{\lambda E^2}{4}. \tag{12.114}$$

显然 $I(0) = 0$，$I(\infty) = H(x)$，从而

$$H(X) = \int d\lambda \, \frac{1}{4}\text{AMP-MSE}(\lambda) > \int \frac{1}{4}\text{MMSE}(\lambda) = H(X). \tag{12.115}$$

因此，原文得出 AMP 几乎处处达到 MMSE、自由能正确的结论。**译注：**这里是原作者的证明思路，依赖所述连续性等条件。原文将 $H(Y \mid X)$ 写在完美恢复的解释中，而相应条件通常涉及 $H(X \mid Y)$；一般连续先验的熵和端点还须另行处理。式 (12.101) 的对称矩阵计数、(12.102) 分母的逗号、(12.104) 的 1/4 约定、自由能指数中额外的 x_0^*、正文导数 $4m^2/4$、(12.108) 未平方且只对 i 求和、后文严格大于号及未定义的 T 均照录；式 (12.115) 字面形成 $H(X) > H(X)$，不视为已完成严格证明。未把无相变条件下的论证推广为所有先验或困难相的算法最优性结论。

12.5 从 AMP 到副本预测的证明：MAP 情形

再考虑尖峰模型。给定 $Y = N^{-1/2}(W + \sqrt{\lambda/N} x_* x_*^T)$，除 X_* 在球面上归一化之外一无所知。通常可采用最大似然估计：在 X 位于球面上的约束下，最小化 $\|Y - \sqrt{\lambda} x x^T\|_2^2$。用代价函数

$$\mathcal{L} = -\sum_{i,j} x_i Y_{ij} x_j + \mu \left(\sum_i x_i^2 - N \right)^2, \tag{12.116}$$

其中 μ 为固定范数的 Lagrange 参数。原文说，满足下列条件即可解出问题：

$$\sum_j Y_{ij} x_j = \mu x_i, \tag{12.117}$$

$$Y \widehat{x} = \mu \widehat{x}. \tag{12.118}$$

即 x 是本征向量。选择观测矩阵的最大本征值，即使损失最小。

看看 AMP 如何处理。使用保持范数的函数，写为

$$x^{t+1} = \left(A + \frac{\sqrt{\lambda}}{N} x_* x_*^T \right) m^t - b_t m^{t-1} = Y m^t - b_t m^{t-1}, \tag{12.119}$$

$$m^t = f_t(x^t), \tag{12.120}$$

其中不可分离函数为

$$f_t(x^t) = x^t \frac{\sqrt{N}}{\|x^t\|_2}, \tag{12.121}$$

$$b_t = \frac{\sqrt{N}}{\|x^t\|_2}. \tag{12.122}$$

设迭代收敛到不动点，求其性质：

$$x = Y x \frac{\sqrt{N}}{\|x^t\|_2} - \frac{\sqrt{N}}{\|x\|_2} x \frac{\sqrt{N}}{\|x\|_2}, \tag{12.123}$$

$$x \left(1 + \frac{N}{\|x\|_2^2} \right) = Y x \frac{\sqrt{N}}{\|x\|_2}, \tag{12.124}$$

$$m\left(\frac{\|x\|_2}{\sqrt{N}}+\frac{\sqrt{N}}{\|x\|_2}\right)=Ym. \tag{12.125}$$

这正是所求的不动点，甚至同时给出了 Lagrange 参数！因此，如果 AMP 收敛，似乎就能解出该问题。再利用状态演化分析其解：$x=Z+q_0\sqrt{\lambda}x_*$，显然 $|x|_2^2=N(1+q_0^2\lambda)$，并有

$$q_0=\mathbb{E}\frac{1}{N}\left(\frac{Z+q_0\sqrt{\lambda}x_0}{\sqrt{1+q_0^2\lambda}}x_0\right)=q_0\frac{\sqrt{\lambda}}{\sqrt{1+q_0^2\lambda}}. \tag{12.126}$$

由此得到

$$q_0=0, \qquad \lambda<1, \tag{12.127}$$

$$q_0=\sqrt{1-\frac{1}{\lambda}}, \qquad \lambda>1. \tag{12.128}$$

这就是 BBP 相变。还可计算本征值：$|x|_2^2=N(1+q_0^2\lambda)$ 变成 $|x|_2^2=N\lambda$，所以

$$\lambda_{\max}=\sqrt{\lambda}+\frac{1}{\sqrt{\lambda}}. \tag{12.129}$$

这给出证明副本预测的一般策略：找到不动点与极小值相符的 AMP，证明其收敛，再研究状态演化预测。**译注：**式 (12.116) 原式确实对约束项平方，这与随后所用线性 Lagrange 约束形式不同；(12.117) 为驻点条件，单凭本征向量性尚不能选择最大本征值。归一化函数的有限维散度与原文简写的 b_t、(12.126) 的 $1/N$ 及 x_0/x_* 记法、BBP 两支的取向选择均保持。最大本征值公式在此由超阈值分支推导，不能当作低于阈值时的谱边缘；收敛仍是所述策略的独立前提。

12.6 矩形 AMP 与 GAMP

本节源自 Bayati 与 Montanari (2011)、Rangan (2011), 但具体讨论采用 Berthier 等 (2020) 以及 Gerbelot 与 Berthier（2021）。

许多问题涉及矩形非对称矩阵 $A\in\mathbb{R}^{m\times n}$，可考察迭代

$$u^{t+1}=A^Tg_t(v^t)-d_te_f(u^t), \tag{12.130}$$

$$v^t=Ae_t(u^t)-b_tg_{t-1}(v^{t-1}), \tag{12.131}$$

其中假设 $\mathbb{E}[A_{ij}^2]=1/n$、$\alpha=m/n$，并取

$$d_t=\frac{\alpha}{m}\operatorname{div}g_t(v^t), \qquad b_t=\frac{1}{n}\operatorname{div}e_t(u^t). \tag{12.132}$$

若有这些方程的状态演化，便可始终将 u,v 视为高斯变量。通过归约到最初的对称递推即可做到！定义

$$A_s=\sqrt{\frac{1}{1+\alpha}}\begin{pmatrix}B & A\\ A^T & C\end{pmatrix}, \qquad x^0=\begin{pmatrix}0\\ u^0\end{pmatrix}, \tag{12.133}$$

$$f_{2t+1}=\sqrt{1+\alpha}\begin{pmatrix}g_t(x_1,\dots,x_m)\\ 0\end{pmatrix}, \qquad f_{2t}=\sqrt{1+\alpha}\begin{pmatrix}0\\ e_t(x_{m+1},\dots,x_{m+n})\end{pmatrix}. \tag{12.134}$$

于是 x^t 遵循通常的 AMP 迭代。A_s 是方差 $1/(n+m)$ 的 $(n+m)\times(n+m)$ 矩阵，$h = A_s s -$ Onsager 项 给出所需方程，注意 d_t 的 Onsager 项里出现的 α 因子。变量替换后，u, v 均为有效高斯变量，可用状态演化计算其方差等。

矩形 AMP 的重要应用是广义线性问题的近似消息传递，称为广义 AMP（GAMP），略作改写为

$$u^{t+1} = A^T g_t^{\text{out}}(\omega^t) + \Sigma_t^{-1} f_t^{\text{in}}(u^t), \tag{12.135}$$

$$\omega^t = A f_t^{\text{in}}(u^t) - V_t g^{\text{out}}(\omega^{t-1}), \tag{12.136}$$

其中 $V_t = \mathbb{E}[e_t'(u^t)]$、$\Sigma_t^{-1} = -\alpha\mathbb{E}[\operatorname{div} g_t]$ 扮演 Onsager 项的角色。状态演化非正式地写为

$$u^t = \sqrt{q_u^t} Z, \qquad \omega^t = \sqrt{q_\omega^t} Z', \tag{12.137}$$

$$q_u^{t+1} = \alpha\mathbb{E}[(g_t^{\text{out}}(\sqrt{q_\omega^t} Z))^2], \qquad q_\omega^t = \mathbb{E}[(f_t^{\text{in}}(\sqrt{q_u^t} Z))^2]. \tag{12.138}$$

这一结果可推广到更有趣的情况。实际问题有一个隐藏的 x_0，观测由 $z = Ax_0$ 的函数给出，因此像 Wigner 尖峰模型一样，需要更一般的描述。

希望函数 g 可通过 y 依赖于 z，而 f 与 x_0 相关。一般 GAMP 为

$$u^{t+1} = A^T g_t^{\text{out}}(\omega^t, Y) + \Sigma_t^{-1} f_t^{\text{in}}(u^t), \tag{12.139}$$

$$\omega^t = A f_t^{\text{in}}(u^t) - V_t g^{\text{out}}(\omega^{t-1}, Y). \tag{12.140}$$

这为 u 增添一个可与 x_0 相关的方向，也为 ω 增添一个可与 z_0 相关的方向。此时状态演化为

$$q_u^{t+1} = \alpha\mathbb{E}[(g_t^{\text{out}}(\omega, \phi(z_0)))^2], \tag{12.141}$$

$$q_\omega^t = \mathbb{E}[f_t^{\text{in}}(\sqrt{q_u^t} Z + m_u^t x_0)^2], \tag{12.142}$$

$$m_u^{t+1} = \alpha\mathbb{E}[\partial_{z_0}(g_t^{\text{out}}(\omega, \phi(z_0)))], \tag{12.143}$$

$$m_\omega^t = \mathbb{E}[f_t^{\text{in}}(\sqrt{q_u^t} Z + m_u^t x_0) x_0]. \tag{12.144}$$

m_u^{t+1} 的方程来自 Stein 引理：

$$m_u^{t+1} = \alpha\mathbb{E}[z_0 g_t^{\text{out}}(\omega, \phi(z_0))] = \alpha\mathbb{E}[\partial_{z_0}(g_t^{\text{out}}(\omega, \phi(z_0)))]. \tag{12.145}$$

z, ω 服从协方差为 $\begin{pmatrix} \rho & m^t \\ m^t & q^t \end{pmatrix}$ 的联合高斯分布；测量函数（可以是随机的）定义为 $Y = \phi(Z_0)$，$Z_0 = AX_0$。**译注：**式 (12.130) 原下标确为 e_f，后文为 e_t；B, C 的随机性假设、散度的归一化及非正式状态演化的适用条件须另行给出。原式中不成对的括号仅作排版配对，未改数学因子。式 (12.145) 涉及相关高斯变量，协方差、方差以及求导所保持的变量需要说明；未将原简写当作无条件的单变量 Stein 恒等式。

12.7 学习问题：LASSO

12.7.1 梯度下降

从初猜 x^0 开始，迭代趋近函数的极小值。每步近似为

$$x^{t+1} = x^t - \eta f'(x^t).$$

为求下一步 x^{t+1}，在当前点附近用二次函数近似原函数，再取该近似的极小值。Taylor 定理给出

$$f(x) \approx f(x^t) + (x - x^t)f'(x^t) + \frac{(x - x^t)^2}{2} f''(x^t).$$

将 $f''(x^t)$ 换成与学习率相应的 η^{-1}，得到

$$f(x) \approx f(x^t) + (x - x^t)f'(x^t) + \frac{(x - x^t)^2}{2\eta}.$$

其极小点满足

$$\begin{aligned} & f'(x^t) + \frac{x^* - x^t}{\eta} = 0, \\ \Rightarrow \quad & x^{t+1} \overset{\text{def}}{=} x^* = x^t - \eta f'(x^t). \end{aligned}$$

因此，每步梯度下降（GD）可写为近似代价函数 $f(x)$ 的最小化。

12.7.2 近端梯度下降

设待优化的 $f(x)$ 在某些点不可导，但可分解为可导与不可导两部分：

$$f(x) = g(x) + h(x), \qquad \begin{cases} g(x) & \text{可导}, \\ h(x) & \text{不可导，例如}|x|. \end{cases}$$

因此，只对 $g(x)$ 作到二阶的梯度近似。将目标乘以相应常数不改变极小点，于是

$$\begin{aligned} f(x) &\simeq g(x^t) + (x - x^t)g'(x^t) + \frac{(x - x^t)^2}{2\eta} + h(x), \\ x^{t+1} &= \operatorname*{argmin}_x \left[(x - x^t)g'(x^t) + \frac{(x - x^t)^2}{2\eta} + h(x) \right] \\ &= \operatorname*{argmin}_x \left[h(x) + \frac{1}{2\eta}(x - x^t + g'(x^t)\eta)^2 \right] \\ &= \operatorname*{argmin}_x \left[h(x)\eta + \frac{1}{2}(x - (x^t - g'(x^t)\eta))^2 \right]. \end{aligned}$$

若 $h(x)$ 不太复杂，可解析求解，这是凸优化中的基本研究对象。

定义：函数的近端算子。

$$\mathrm{Prox}_{l(\cdot)}(z) = \operatorname*{argmin}_x \left[l(x) + \frac{1}{2}(x - z)^2 \right].$$

例：软阈值， $l(x) = a|x|$。

$$\mathrm{Prox}_{l(\cdot)}(z) = \begin{cases} z - a, & z \geq a, \\ 0, & z \in [-a, a], \\ z + a, & z \leq -a. \end{cases}$$

递推为

$$x^{t+1} = \mathrm{Prox}_{\eta h(\cdot)}[x^t - \eta g'(x^t)].$$

12.7.3 LASSO 及其他线性问题

一个典型问题是求下面函数的极小点：

$$\mathcal{L}(w)=\frac{1}{2}\|y-Aw\|_2^2+h(\lambda). \tag{12.146}$$

当 h 为凸函数时，可用近端梯度下降（PGD），递推为

$$w^{t+1}=\mathrm{Prox}_{\eta h(\cdot)}[w^t-\eta\mathcal{L}'(x^t)]=\mathrm{Prox}_{\eta h(\cdot)}[w^t+\eta A^T(y-Aw)].$$

译注：原损失确实写 $h(\lambda)$，后面的递推则使用作用于待估计量的惩罚函数；x/w 及导数记法按原文保留。最小化目标乘以常数时还需该常数为正，近端算子的单值性和下降收敛也需要相应条件。

12.7.4 再看 AMP

考虑 AMP 递推

$$x^{t+1}=f_t(x^t+A^Tr^t/\alpha), \tag{12.147}$$

$$r_t=y-Ax+\frac{1}{\alpha}b_tr^{t-1}. \tag{12.148}$$

它显然是 GAMP 的实例。取 $g_t(v^t)=y-v^t=r^t$、$e(u)=\mathrm{Prox}(u/\alpha)$，则

$$u^{t+1}=A^T(y-v^t)+\alpha\,\mathrm{Prox}(u^t/\alpha), \tag{12.149}$$

$$v^t=A\,\mathrm{prox}(u^t/\alpha)-V_tg_{t-1}(v^{t-1}). \tag{12.150}$$

使用 $x=\mathrm{prox}(u/\alpha)$ 和 $r=y-v$，有

$$u^{t+1}=A^Tr_t+\alpha x, \tag{12.151}$$

$$r^t=y-v^t=y-A\,\mathrm{prox}(u^t)+b_tg_{t-1}(v^{t-1})=y-Ax+V_tr, \tag{12.152}$$

其中 $V_t=\alpha^{-1}\mathbb{E}[\mathrm{prox}'(u/\alpha)]$。

所以可对这个 AMP 实例写出状态演化。关键是，若 AMP 收敛，在某时刻 t^* 有

$$r_{t^*}=\frac{y-Ax}{1-b_{t^*}/\alpha}, \tag{12.153}$$

$$x=\mathrm{Prox}_{t^*}\left(x+\frac{A^T(y-Ax)}{\alpha-b_{t^*}}\right). \tag{12.154}$$

这就是参数 $\eta=1/(\alpha-b)$ 的近端优化算法不动点。原文据此说：采用相应 AMP 递推，便可求解 LASSO，乃至任何凸优化问题!

在最简单的 $y=Ax_0+\sqrt{\Delta}\xi$ 情形，u,v 均为高斯变量，需要跟踪其方差以及在 x_0,y 方向的投影：

$$\begin{aligned}q_u^{t+1}&=\alpha\mathbb{E}[(g_t^{\mathrm{out}}(\omega,\phi(z_0)))^2]=\alpha\mathbb{E}[(y-w)^2]=\alpha(\rho+q_\omega-2m_\omega+\Delta)\\&=\alpha(E^t+\Delta),\end{aligned} \tag{12.155}$$

$$q_\omega^t=\mathbb{E}[e_t^{\mathrm{in}}(\sqrt{q_u^t}Z+m_u^tx_0)^2], \tag{12.156}$$

$$m_u^{t+1} = \alpha \mathbb{E}[\partial_{z_0}(g_t^{\text{out}}(\sqrt{q_\omega^t}Z' + m_\omega^t z_0, \phi(z_0)))] = \alpha, \tag{12.157}$$

$$m_\omega^t = \mathbb{E}[e_t^{\text{in}}(\sqrt{q_u^t}Z + m_u^t x_0)x_0]. \tag{12.158}$$

只保留 q, m 并采用前面的近端算子，可写为

$$q^{t+1} = \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(\rho + q^t - 2m^t + \Delta)}Z + x_0)^2], \tag{12.159}$$

$$m^{t+1} = \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(\rho + q^t - 2m^t + \Delta)}Z + x_0)x_0]. \tag{12.160}$$

更直接地，

$$\begin{aligned} E^{t+1} = \rho &+ \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(E^t + \Delta)}Z + x_0)^2] \\ &- 2\mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(E^t + \Delta)}tZ + x_0)x_0]. \end{aligned}$$

译注： 原文残差的 r_t/r^t、V_t/b_t、(12.152) 中缺少的 $/\alpha$、w/ω 及最后一式额外的 tZ 均保持。相同不动点并不自动证明 AMP 收敛或可求解任意凸优化；还需正步长、惩罚的匹配、矩阵系综及相应收敛条件。

12.7.5 岭回归的例子

采用岭回归，近端算子为 $f_{\lambda\eta}(u) = u/(\lambda\eta+1)$。收敛后，由 $\eta = 1/(\alpha - b_{\text{eq}})$、$b_{\text{eq}} = 1/(\lambda\eta+1)$，必有[9]

$$b_{\text{eq}} = \frac{1}{1 + \lambda/(\alpha - b_{\text{eq}})}.$$

接下来的方程是

$$q = \frac{1 + \alpha^{-1}(1 + q - 2m + \Delta)}{(\lambda/(\alpha - b) + 1)^2}, \tag{12.161}$$

$$m = \frac{1}{\lambda/(\alpha - b) + 1} = \frac{\alpha - b}{\lambda + \alpha - b}. \tag{12.162}$$

当 $\alpha > 1$ 时，$\lambda = 0$ 有一个有趣的解：$m = 1$，且

$$\begin{aligned} q &= 1 + \alpha^{-1}(1 + q - 2 + \Delta), \\ q(1 - \alpha^{-1}) &= 1 + (\Delta - 1)/\alpha, \\ q &= \frac{1 - \alpha^{-1} + \Delta/\alpha}{1 - \alpha^{-1}} = 1 + \frac{\Delta}{\alpha - 1}. \end{aligned}$$

恢复信号的误差为 $E = \Delta/(\alpha - 1)$，在 $\alpha = 1$ 发散！

还有另一种极限。取 $b = \alpha - \lambda c$，在 $\lambda \to 0^+$ 时求解 c，得到对应 “伪范数” 的解 $b = \alpha$。这适用于 $\alpha < 1$。此时 $m = \alpha$，并有

$$\begin{aligned} q &= \alpha^2(1 + \alpha^{-1}(1 + q - 2\alpha + \Delta)) \\ &= \alpha^2 + \alpha + \alpha q - 2\alpha^2 + \alpha\Delta, \\ q(1 - \alpha) &= \alpha(1 - \alpha + \Delta), \end{aligned}$$

[9] 有些论文使用变量替换 $V/(1+V) = b/\alpha$，得到自洽方程 $V_{\text{eq}} = 1/(\lambda + \alpha/(1 + V_{\text{eq}}))$。

$$q = \frac{\alpha(1-\alpha+\Delta)}{1-\alpha}.$$

误差为 $E = 1 + \alpha(1-\alpha+\Delta)/(1-\alpha) - 2\alpha$，即原文写出的

$$E = \frac{1+\alpha+\alpha(1-\alpha+\Delta)-2\alpha+2\alpha^2}{1-\alpha} = \frac{1+\alpha\Delta+\alpha^2}{1-\alpha}.$$

因此，当 $\lambda \to 0^+$ 时，泛化误差 $E+\Delta$ 为

$$\epsilon_{\text{gen}} = \frac{1+\alpha^2+\Delta}{1-\alpha}, \qquad \alpha < 1, \tag{12.163}$$

$$\epsilon_{\text{gen}} = \frac{\Delta\alpha}{1-\alpha}, \qquad \alpha > 1. \tag{12.164}$$

此外，仍有

$$r_{t^*} = \frac{y - Ax}{1 - b_{t^*}/\alpha}. \tag{12.165}$$

因此，训练误差（原文称向量 $y-Ax$ 的平均值）与 r 的误差满足

$$\epsilon_{\text{train}} = \mathbb{E}[(y-Ax)^2] = \mathbb{E}[r^2]\left(1-\frac{b}{\alpha}\right)^2 = \epsilon_{\text{gen}}\left(1-\frac{b}{\alpha}\right)^2. \tag{12.166}$$

在 $\lambda \to 0^+$ 时得到

$$\epsilon_{\text{train}} = 0, \qquad \alpha < 1, \tag{12.167}$$

$$\epsilon_{\text{train}} = \frac{\Delta(\alpha-1)}{\alpha}, \qquad \alpha > 1. \tag{12.168}$$

译注： 原文在 $\alpha < 1$ 分支的通分中写出 $1+\alpha$，与前行不相符；(12.164) 的分母 $1-\alpha$ 会使 $\Delta > 0, \alpha > 1$ 时误差为负，亦与前文 $E = \Delta/(\alpha-1)$ 不符。此处忠实保留并定位，不把这些负误差公式作为已核实的统计结果；“伪范数” 为原文用词。

12.8 用 GAMP 推断

本节考虑如下推断问题。已知矩阵 $F_{\mu i}$，观测一个 M 维向量 y_μ（$\mu = 1, \ldots, M$），其每个分量依赖于未知 N 维向量 x_i（$i = 1, \ldots, N$）的线性投影：

$$y_\mu = f_{\text{out}}\left(\sum_{i=1}^{N} F_{\mu i} x_i\right). \tag{12.169}$$

输出函数 f_{out} 包括噪声。例如，加性白高斯噪声（AWGN）的输出是 $f_{\text{out}}(x) = x + \xi$，$\xi$ 为高斯随机变量；线性阈值输出是 $f_{\text{out}}(x) = \text{sign}(x-\kappa)$，其中 κ 为阈值。线性估计的目标是根据 y, F, f_{out} 推断 x。另一种表述是记 $z_\mu = \sum_{i=1}^{N} F_{\mu i} x_i$，用给定 z 后观测到 y 的似然

$$P(y \mid z) = \prod_{\mu=1}^{M} P_{\text{out}}(y_\mu \mid z_\mu). \tag{12.170}$$

使用

$$g_{\text{out}}(\omega, y, V) \equiv \frac{\int dz\, P_{\text{out}}(y \mid z)(z-\omega)e^{-(z-\omega)^2/(2V)}}{V \int dz\, P_{\text{out}}(y \mid z) e^{-(z-\omega)^2/(2V)}}, \tag{12.171}$$

以及（$R = u * \Sigma$）

$$f_{\rm in}(\Sigma, R) = \frac{\int dx\, x P_X(x) e^{-(x-R)^2/(2\Sigma)}}{\int dx\, P_X(x) e^{-(x-R)^2/(2\Sigma)}}, \qquad f_v(\Sigma, R) = \Sigma \partial_R f_a(\Sigma, R). \tag{12.172}$$

这些方程并非新事物！Mézard 早在 1989 年就把它们写成所谓感知机问题的 TAP 方程（原引文 “?”）。Kabashima（原引文 “?”）及 Krzakala 等（原引文 “?”）也写出过相同方程。这里采用的形式来自 Rangan (2011)。**译注：** 末式左侧使用 $f_{\rm in}$，导数内却写 f_a，以及 $u * \Sigma$ 的乘法记号，均按源保留。一般非线性输出问题也包含于此，不把原文 “线性估计” 限定为仅有线性观测函数。

第三部分：随机约束满足问题

13 图着色 II：从植入得到的启示

13.1 SBM 与植入着色

考虑随机块模型的特例：$n_a = 1/q$、$c_{aa} = c_{\rm in}$，且 $a \neq b$ 时 $c_{ab} = c_{\rm out}$。$c_{\rm in} > c_{\rm out}$ 称为同配 / 铁磁情形，即组内连边比组间更可能；$c_{\rm in} < c_{\rm out}$ 称为异配 / 反铁磁情形，即组内连边比组间更不可能。

上一讲导出了随机块模型的信念传播方程：

$$\begin{aligned} \chi_{t_i}^{i\to j} &= \frac{1}{Z^{i\to j}} n_{t_i} e^{-h_{t_i}} \prod_{k\in \partial i\backslash j} \left[\sum_{t_k} c_{t_k t_i} \chi_{t_k}^{k\to i} \right] \\ &= \frac{1}{Z^{i\to j}} n_{t_i} e^{-h_{t_i}} \prod_{k\in \partial i\backslash j} [c_{\rm out} - (c_{\rm in} - c_{\rm out}) \chi_{t_i}^{k\to i}], \end{aligned} \tag{13.1}$$

辅助外场汇总了非边的贡献及总体影响：

$$h_{t_i} = \frac{1}{N} \sum_k \sum_{t_k} c_{t_k t_i} \chi_{t_k}^{k}. \tag{13.2}$$

定义

$$e^{-\beta} = \frac{c_{\rm in}}{c_{\rm out}}, \tag{13.3}$$

将不依赖 t_i 的项并入归一化 $Z^{i\to j}$，得到

$$\chi_{t_i}^{i\to j} = \frac{1}{Z^{i\to j}} n_{t_i} e^{-h_{t_i}} \prod_{k\in \partial i\backslash j} [c_{\rm out} - (c_{\rm out} - c_{\rm in}) \chi_{t_i}^{k\to i}], \tag{13.4}$$

$$\chi_{t_i}^{i\to j} = \frac{1}{Z^{i\to j}} n_{t_i} e^{-h_{t_i}} \prod_{k\in \partial i\backslash j} c_{\rm out} \left[1 - \left(1 - \frac{c_{\rm in}}{c_{\rm out}} \right) \chi_{t_i}^{k\to i} \right]. \tag{13.5}$$

再将 $c_{\rm out}$ 并入归一化，最终得到

$$\chi_{t_i}^{i\to j} = \frac{1}{Z^{i\to j}} n_{t_i} e^{-h_{t_i}} \prod_{k\in \partial i\backslash j} [1 - (1 - e^{-\beta}) \chi_{t_i}^{k\to i}]. \tag{13.6}$$

这里沿用同一符号表示新归一化，略有记号滥用。它与第 6 节中图着色的 BP 十分接近：

$$\chi_{t_i}^{i\to j} = \frac{1}{Z^{i\to j}} \prod_{k\in\partial i\setminus j} [1-(1-e^{-\beta})\chi_{t_i}^{k\to i}]. \tag{13.7}$$

唯一区别是后式没有 $n_{t_i}e^{-h_{t_i}}$，它对应固定正确组大小的先验。在异配 / 反铁磁情形 $c_{\text{in}} < c_{\text{out}}$（即 $\beta > 0$）且组大小相等 $n_a = 1/q$（$a = 1, \dots, q$）时，无须这一项，它渐近地不影响 BP 的迭代行为。可分别运行带此项和不带此项的 BP 作经验验证，但形式化数学证明并不平凡。**译注：**式 (13.1) 中 $c_{\text{in}} - c_{\text{out}}$ 与紧接着的式 (13.4) 相反，按各处原式保留；省略外场的论断也保留原文的渐近和经验性质。

本节参数下的 SBM 可视为有限逆温度 $\beta > 0$ 的植入着色问题，定义如下。

- 从 N 个节点、q 种颜色开始，每个节点随机获得真实颜色 $s_i^* \in [q] := \{1, \dots, q\}$。
- 在节点间随机放置 $M = cN/2$ 条边，使其中 $c_{\text{out}}(q-1)/(cq)$ 的比例连接不同颜色，其余连接相同颜色。该比例使组间边的期望数与 SBM 一致。由此产生邻接矩阵 $A = [A_{ij}]_{i,j=1}^N$。

目标是根据 A 和参数 θ 找到真实构型 s^*，允许整体颜色置换。称之为“植入”，是因为先植入真实分组，再围绕它构造待着色的图。逆温度 β 与单色边比例相关。

图 10.4.3 所示 $q = 5$、$\beta \to \infty$ 的 SBM 中，c_d, c_c, c_ℓ 三个阈值也存在于植入着色。更有意思的是，它们对最初的非植入图着色问题也有影响。

13.2 植入与随机图着色的关系

13.2.1 BP 收敛与算法阈值

对 SBM，已导出当

$$|c_{\text{in}} - c_{\text{out}}| > q\sqrt{c} \tag{13.8}$$

时，BP 收敛到与真实分组具有正重叠的构型。用 β 和平均度 c 表示，条件为

$$c > c_\ell = \left(\frac{q-1+e^{-\beta}}{1-e^{-\beta}}\right)^2. \tag{13.9}$$

在 SBM 中，这个算法相变标志着 BP 能找到与真实分组最优重叠的相的开始。

上述相变由顺磁 BP 不动点的稳定性导出。植入与随机图着色的 BP 方程相同，因此其稳定性也适用于随机图着色。在第 6 节末，已导出随机图着色 BP 何时收敛到顺磁不动点、何时远离它的条件，见式 (6.24)（源文此处引为 6.24）。它恰是式 (13.9)。实际上，在普通非植入着色中，$c > c_\ell$ 时 BP 不收敛。

c_ℓ 的作用分为四种情况：

- $c > c_\ell$，植入着色：随机初始化的 BP 收敛到与植入构型正重叠的构型。
- $c > c_\ell$，普通着色：随机初始化的 BP 不收敛。
- $c < c_\ell$，植入着色：随机初始化的 BP 收敛到顺磁不动点。
- $c < c_\ell$，普通着色：随机初始化的 BP 收敛到顺磁不动点。

下面比较 $c_{\mathrm{in}}=0$（即 $\beta\to\infty$）时 BP 收敛阈值、可着色阈值的估计，以及大量颜色时尚无已知可证明多项式算法找到正常着色的平均度。表中可见，BP 收敛与可着色性、寻找正常着色的困难性关系不大。在植入情形，它是植入着色推断开始变得算法上容易的阈值；在非植入情形，c_ℓ 这一 BP 收敛阈值并无对应的算法后果。

颜色数	平均度范围	原图列出的性质
$q=3$	$c<c_\ell=(q-1)^2=4$	可着色，BP 收敛
	$4<c<c_{\mathrm{col}}\approx 5.4$	可着色，BP 不收敛
	$c>c_{\mathrm{col}}$	不可着色，BP 不收敛
$q=5$ $(q>3)$	$c<c_{\mathrm{col}}\approx 14.4$	可着色，BP 收敛
	$c_{\mathrm{col}}<c<c_\ell=(q-1)^2=16$	不可着色，BP 收敛
	$c>c_\ell$	不可着色，BP 不收敛
$q\gg 1$	$c<q\log q$	存在多项式算法
	$q\log q<c<c_{\mathrm{col}}\sim 2q\log q$	没有已知多项式算法
	$c_{\mathrm{col}}<c<c_\ell=(q-1)^2$	不可着色，BP 收敛
	$c>c_\ell$	不可着色，BP 不收敛

译注：表格重排原文未编号的三条示意轴；近似阈值和大 q 渐近量保持原文精度，不把端点画线当作临界点的完整分类。局部稳定性分析本身不足以证明所有初始化或所有系综中的全局收敛、最优重叠或不收敛；以上陈述保留本讲的模型与算法语境。

13.2.2 随机与植入系综的相接性及成簇

回顾 SBM 的阈值 c_c（连续相变中 $c_c=c_\ell$）：

- $c<c_c$ 时，最大自由熵的 BP 不动点是顺磁不动点，$\chi_a^{i\to j}=n_a$、$Q=0$。
- $c>c_c$ 时，最大自由熵的 BP 不动点是铁磁不动点，$Q>0$。

图 10.4.3 给出了例子。$c<c_c$ 时，顺磁不动点给出大多数变量的精确边缘以及主导阶精确自由熵。

若顺磁不动点正确描述边缘、重叠及自由能，图中便没有能找出与植入构型相关的构型的信息。原文据此认为，只有植入与非植入图在大图极限下一切高概率性质都相同时，这才可能成立。大尺寸极限的高概率性质在物理中称为热力学性质。数学上，以高概率性质无法区分两个图系综（随机与植入）的性质称为**相接性**（contiguity）。因此，$c<c_c$ 时两系综相接，热力学性质不可区分。这还意味着顺磁 BP 不动点和相应 Bethe 自由熵，不仅对植入图，而且对随机图，在主导阶上精确。下一讲将看到，$c>c_c$ 时不再如此，从而回答 BP 对图着色是否正确的一个主要问题。

贝叶斯最优推断的 Nishimori 恒等式说明，植入构型具有从后验分布随机抽样的构型的全部性质。结合 $c<c_c$ 时两系综的相接性，就能以独特的方式考察随机系综中平衡构型的性质。

在 SBM 一节，通过经验观察发现，BP 不动点与对应初始化的 Monte Carlo Markov 链在随系统大小线性增长的时间里获得的边缘，在大尺寸极限中相当，只是 MCMC 收敛更慢。因此原文得出：若从植入初始化出发的 BP 收敛到顺磁不动点，即 $c<c_d$，MCMC 便可平衡，在总

线性时间内正确估计所有集中量的主导阶。因此，$c < c_d$ 时，MCMC 等动力学每节点经过 $O(1)$ 步即可平衡；从物理角度看，这是液体相而非玻璃相。

当植入模型发生一阶相变，即 $c_d < c_c$ 时，$c_d < c < c_c$ 的相很有意思。所有 $c < c_c$ 时随机与植入系综相接，而在植入系综中，从植入构型初始化的 BP 收敛到与其强相关的 $Q > 0$ 不动点。原文利用相接性推断，在随机系综中，从 Boltzmann 分布均匀抽样的构型初始化 BP，也会得到类似不动点。它描述相同初始化的 MCMC 能采样的子空间，故从平衡初始化出发的动力学会困在初态附近，无法在线性时间内遍历全部相空间。动力学所困住的吸引域称为**簇**。$c_d < c < c_c$ 时，随机初始化 MCMC 无法平衡，即无法近乎均匀地采样构型空间。因此猜想，在这一相中，从 Boltzmann 测度均匀采样构型在算法上困难。

可用 BP 不动点的等价类给出一种簇的定义：考虑逆温度 β 的随机图着色问题，从所有可能构型初始化相同温度的 BP，将各次迭代推进到不动点。所有收敛到同一不动点的初始构型定义为一个簇，即关于 BP 不动点的等价类。若某些构型出发的 BP 不收敛，可以将全部这类构型视为一个簇。虽然这一操作定义未必容易与 Gibbs 态等更物理的概念联系，却最容易转化为分析簇组织的方法，例如计算给定自由熵的簇数。

对应 BP 不动点的自由熵 Φ_{ferro} 描述簇大小。$c < c_c$ 时，总平衡自由熵是顺磁值 Φ_{para}；在 $c_d < c < c_c$ 内，严格有 $\Phi_{\text{para}} > \Phi_{\text{ferro}}$。若平衡解所在的簇的自由熵为 Φ_{ferro}，而总自由熵为 Φ_{para}，则这种簇有 $e^{N(\Phi_{\text{para}}-\Phi_{\text{ferro}})}$ 个。簇复杂度定义为其数目对数除以节点数：

$$e^{N\Sigma} = \text{簇的数目}, \tag{13.10}$$

$$\Sigma = \Phi_{\text{para}} - \Phi_{\text{ferro}}, \tag{13.11}$$

适用于 $c \in (c_d, c_c)$。由于铁磁不动点在 c_d 处不连续出现，指数多个簇也不连续出现。当 $c \to c_c$ 时，$\Sigma \to 0$。

- $c < c_d$：大多数构型属于同一簇，MCMC 能在线性时间内平衡。
- $c_d < c < c_c$：构型属于指数多个簇之一，MCMC 无法在线性时间内平衡。

阈值前能够平衡、阈值后不能在线性时间内平衡，正是“动力学阈值”一名的由来。

目前定位成簇阈值 c_d 的方法，是从随机及植入不动点出发运行 BP 并比较自由熵。它比较费力，不能像线性稳定性阈值 c_ℓ 那样给出简单闭式。下一节对正常着色 $c_{\text{in}} = 0$（$\beta \to \infty$）给出 c_d 的闭式上界。**译注：**相接性是系综序列关于稀有事件的数学性质；无可用正重叠信息，并不单独推出所有高概率图性质相同。这里保留作者的物理推理和经验动态对应，不将其改写为一般相接性定理或 MCMC 混合时间证明。给定有限温度时“均匀”一词亦保留原语境；Boltzmann 测度通常带非均匀权重。簇复杂度的差值计算针对文中描述的典型簇尺度，不替代所有簇自由熵分布的计数。

13.2.3 成簇阈值的上界

零温 $\beta \to \infty$ 时，从一个解（正常着色）初始化的 BP 不动点可能有**冻结变量**，即从初态到不动点一直保持初值的变量 i。这意味着同一簇全部解中该变量均取相同值。原文给出：若 BP 不动点仍满足 $\chi_s^{j\to i} = \delta_{s,s_j^*}$，则变量 i 冻结；若簇内有限比例变量冻结，则该簇为**冻结簇**。

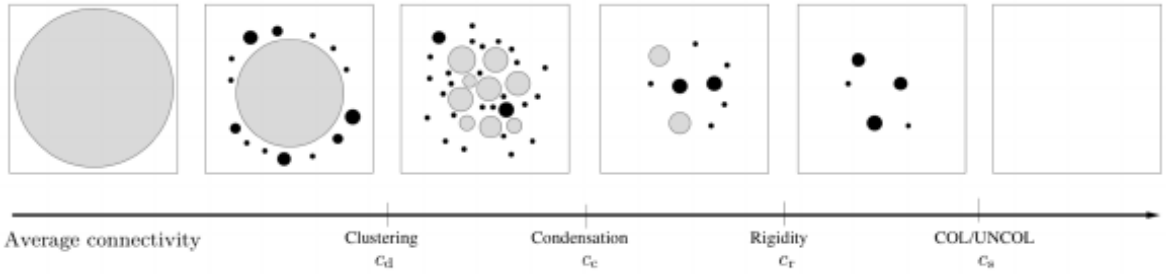


图 13.2.1: 随机图着色问题中正常着色解空间的示意图。灰圆表示非冻结簇，黑圆表示冻结簇，圆的大小表示簇大小。横轴为平均连通度；从左向右依次标出成簇 c_d、凝聚 c_c、刚性 c_r 及可着色 / 不可着色分界 c_s。图为源物理页 222 的忠实裁取。

为判断随机抽取的解所在簇是否冻结，回顾随机与植入系综的相接性及植入构型具有平衡构型全部性质这一点。于是可从植入构型初始化 BP，跟踪更新中有多少变量冻结，以找出典型簇冻结的阈值。

考虑简单情形：d 正则随机图，在 $N \to \infty$ 时局部树状。取某节点周围的有根树。植入解可视为树上的广播过程：根取某颜色，随后递归地给各子节点（朝叶方向的邻居）随机分配其余颜色之一。有无冻结变量便转化为：深树的叶颜色是否迫定根颜色，还是根可取别的颜色，同时满足着色规则和叶颜色。

记 η_ℓ 为第 ℓ 代节点被其上方叶节点迫定的概率，即只能取一个颜色（植入颜色）。仅当其余每一种颜色至少被一个子节点迫定时，该节点才被迫取植入颜色。因此

$$\begin{aligned}\eta_\ell &= \Pr(\text{第}\ell\text{ 代节点被其叶节点迫定})\\ &= \Pr(\text{第}\ell\text{ 代节点的子节点迫定了其余全部}q-1\text{ 种颜色})\\ &= 1-\Pr(\text{第}\ell\text{ 代节点至少有一种其余颜色未被子节点迫定}).\end{aligned}$$

假设其余 $q-1$ 种颜色中指定的 r 种，都不被任何一个 $d-1$ 个子节点迫定，其概率为

$$\begin{aligned}&\Pr(\text{第}\ell\text{ 代节点的指定}r\text{ 种颜色均未被任一子节点迫定})\\ &= \{\Pr(\text{指定}r\text{ 种颜色不被给定子节点迫定})\}^{d-1}\\ &= \{1-\Pr(\text{给定子节点被迫取指定}r\text{ 种颜色之一})\}^{d-1}\\ &= \left[1-\frac{r\eta_{\ell+1}}{q-1}\right]^{d-1}.\end{aligned}$$

接着应用容斥原理。$r=1$ 时重复计入了实际有两种颜色未被迫定的情况，依此类推，得到

$$\begin{aligned}\eta_\ell &= 1-\sum_{r=1}^{q-1}(-1)^{r-1}\binom{q-1}{r}\\ &\qquad\cdot\Pr(\text{第}\ell\text{ 代的指定}r\text{ 种颜色均未被任一子节点迫定})\\ &= 1+\sum_{r=1}^{q-1}(-1)^{r}\binom{q-1}{r}\left[1-\frac{r\eta_{\ell+1}}{q-1}\right]^{d-1}.\end{aligned}$$

最终得到单变量递推

$$\eta_\ell = 1 + \sum_{r=1}^{q-1} (-1)^r \binom{q-1}{r} \left[1 - \frac{r\eta_{\ell+1}}{q-1}\right]^{d-1}.$$

对深度 d 的树，从 $\eta_d = 1$ 开始，因为第 d 代节点本身就是叶。向根推进时更新 η_ℓ，直到不动点。

定义**刚性阈值** c_r：

- $d > c_r$ 时，不动点 $\eta > 0$。
- $d < c_r$ 时，不动点 $\eta = 0$。

c_r 给出动力学阈值 c_d 的上界。颜色数少时二者并不很近，$q < 9$ 时刚性阈值甚至高于 c_c。但 $q \gg 1$ 时，展开得到 $c_r = q\log q + o(q\log q)$。因此，大量颜色时，从至少 c_r 的平均度起，包含典型解的簇以高概率冻结。

虽然上述论证针对 d 正则树，对度数涨落的随机树也能得到类似闭式，且大 q 的主导阶行为相同。**译注：**冻结变量定义句中的变量 i 与消息所对应的 j 不一致；度数和树深均使用 d，按原文保留。递推中的 $d-1$ 对应朝根的空腔分支，根的全部邻居数与此须区分。利用植入系综分析典型平衡解，需要前述相接性的适用范围，不能只由正则树递推无条件覆盖所有随机图参数。

13.2.4 评论与文献

植入与随机系综的相接性，只在顺磁（或类似）不动点存在时才可能成立。在随机 K-SAT 等一般问题中，植入系综总与随机系综不同。不过，成簇、簇是 Monte Carlo 采样吸引域的观点，以及 BP 不动点定义，具有更广泛的适用性，并不限于两类系综相关联的模型。

大量颜色时刚性阈值 $c_r \approx q\log q$，与目前没有已知可分析算法奏效的尺度一致。此外，文献数值检验表明，多项式算法找到的解不产生冻结 BP 不动点，由此猜想冻结解难以找到。但刚性阈值描述典型簇冻结，仍可能有非典型簇，在更高平均度下保持非冻结。类比已经分析的相关约束满足问题，确实预期如此，参见 Braunstein 等（2016）。总体上，寻找解何时变难的精确阈值，即使在猜想层面也仍未解决。

14 图着色 III：可着色阈值与簇的性质

14.1 成簇分析：一般讨论

上一节推断，在一段参数范围内，随机图着色的解空间分裂成所谓的簇。簇对应 BP 不动点，其自由熵对应不动点的 Bethe 自由熵 Φ_{Bethe}。因此，可以像分析给定能量 / 成本的构型数那样，分析给定自由熵的簇数。定义复杂度函数 $\Sigma(\Phi_{\mathrm{Bethe}})$ 为该自由熵下 BP 不动点数目的对数除以节点数，再定义**副本自由熵** $\Psi(m)$：

$$e^{N\Psi(m)} = \sum_{\text{BP 不动点}} e^{Nm\Phi_{\mathrm{Bethe}}} = \int_\Phi e^{N[\Sigma(\Phi)+m\Phi]}. \tag{14.1}$$

如同能量、熵与自由熵之间的关系，由鞍点和 Legendre 变换的性质，有

$$\frac{\partial\Sigma(\Phi)}{\partial\Phi} = -m, \qquad \frac{\partial\Psi(m)}{\partial m} = \Phi. \tag{14.2}$$

因此，一旦算出 $\Psi(m)$，便能求给定自由熵的簇数 $\Sigma(\Phi)$。

现在确定包含平衡构型（从 Boltzmann 测度随机抽样的构型）的簇的自由熵 Φ。应将总自由熵 $\Phi+\Sigma(\Phi)$ 最大化。BP 不动点是可计数结构，存在的结构至少有一个，正整数的对数非负，故还需 $\Sigma(\Phi)\geq 0$。系统平衡由

$$\max_{\Phi}[\Phi+\Sigma(\Phi)\mid \Sigma(\Phi)\geq 0] \tag{14.3}$$

描述。

最大化有两种情况。假设对应 $m=1$ 附近，复杂度不为零，至多在一点过零。定义 Φ_1 为复杂度曲线斜率等于 -1 的自由熵：

$$\left.\frac{\partial\Sigma(\Phi)}{\partial\Phi}\right|_{\Phi_1}=-1. \tag{14.4}$$

- 若 $\Sigma(\Phi_1)>0$，式 (14.3) 在 Φ_1 最大化，该自由熵的簇数呈指数增长，由 $\Sigma(\Phi_1)$ 给出。这称为动力学一步副本对称性破缺相。

- 若 $\Sigma(\Phi_1)<0$，最大化式 (14.3) 的自由熵，是满足 $\Sigma(\Phi)>0$ 的最大 Φ，记为 Φ_0。此时自由熵主要来自最大的簇，它们不是指数多个；事实上，有限多个最大簇可承载任意接近全部的权重。平衡凝聚于少数大簇，称为静态一步副本对称性破缺相。

在两系综相接的问题中，上一讲 $c_d<c<c_c$ 的复杂度差值 (13.11) 恰等于 $\Sigma(\Phi_1)$，在凝聚阈值 c_c 归零。$c>c_c$ 时，平衡不再由 Φ_1 的簇（即植入簇的自由熵）描述，而由复杂度归零处的 Φ_0 描述。

平均度进一步增加，复杂度曲线最大值降到零，最后的簇消失，标志着可着色阈值。故计算可着色阈值需要计算全部簇的数目，对应 $\Sigma(\Phi)$ 的最大值。**译注：** 原文把 $\Sigma>0$ 的最大 Φ 与零复杂度边界 Φ_0 相连，严格正不等式下可能只有上确界；此处保留原文。鞍点与 Legendre 关系按大 N 主导阶理解，曲线形状、可实现簇及凝聚权重的描述均须相应假设，不能只由整数计数推出全部结论。

14.2 分析 BP 不动点

若能算出式 (14.1) 的 $\Psi(m)$，便可了解簇的诸多性质。它是对所有 BP 不动点求 Bethe 自由熵指数的 m 次幂之和，更明确地，

$$e^{N\Psi(m)}=\sum_{\text{BP 不动点}} e^{m[\sum_i \log Z^i+\sum_a \log Z^a-\sum_{(ia)}\log Z^{ia}]}. \tag{14.5}$$

Z^i, Z^a, Z^{ia} 是先前推导 BP 时得到的 Bethe 自由熵贡献。将 BP 示意写为

$$\chi^{i\to a}=F_\chi(\{\psi^{b\to i}_{b\in\partial i\setminus a}\}), \tag{14.6}$$

$$\psi^{a\to i}=F_\psi(\{\chi^{j\to a}_{j\in\partial a\setminus i}\}). \tag{14.7}$$

副本自由熵可写为

$$e^{N\Psi(m)}=\int\prod_{(ia)}[d\chi^{i\to a}d\psi^{a\to i}]e^{m[\sum_i \log Z^i+\sum_a \log Z^a-\sum_{(ia)}\log Z^{ia}]} \tag{14.8}$$

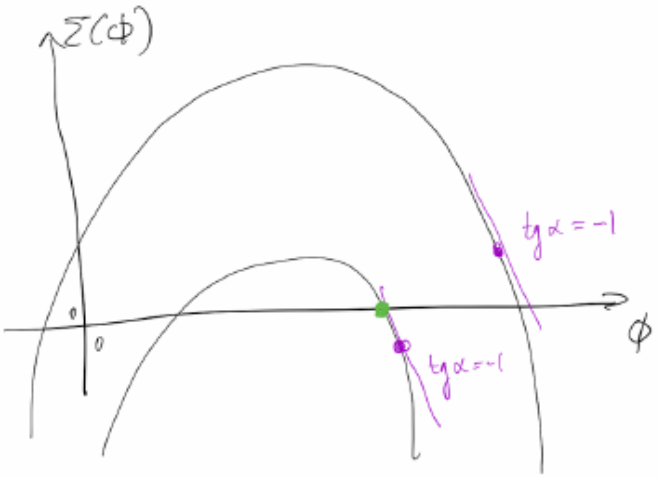


图 14.1.1: 复杂度曲线 $\Sigma(\Phi)$：每节点簇数的对数与簇自由熵 Φ 的关系。紫色标出斜率为 -1 的点；Legendre 变换使曲线斜率为 $-m$。保留源物理页 227 的手绘曲线。

$$\times \prod_i \prod_{a\in\partial i} \delta[\chi^{i\to a} - F_\chi(\{\psi^{b\to i}_{b\in\partial i\setminus a}\})]$$
$$\times \prod_a \prod_{i\in\partial a} \delta[\psi^{a\to i} - F_\psi(\{\chi^{j\to a}_{j\in\partial a\setminus i}\})]. \tag{14.9}$$

这很自然地是原图上辅助问题的配分函数：变量 $(\chi^{i\to a}, \psi^{a\to i})$ 和场 $(Z^{ia})^m$ 位于原边上，因子位于原变量节点 i 与原因子节点 a。

因此，计算副本自由能 $\Psi(m)$ 的问题已可直接应用第 5.2 节的 BP。区别只是变量为连续实数，辅助问题的消息是概率分布。基于 BP 消息独立性的假设，还可以一致地假设，辅助问题中 $i\to a$ 方向的新 BP 消息不依赖反方向的原消息。于是得到一般形式的**调查传播**：现在传递的不是消息，而是消息的分布。它们也称为**一步副本对称性破缺空腔方程**；用副本法导出同样结果则费力得多，也不够直观。参数 m 称为 Parisi 参数。 方程为

$$P^{a\to i}(\psi^{a\to i}) = \frac{1}{\mathcal{Z}^{a\to i}} \int \prod_{j\in\partial a\setminus i} dP^{j\to a}(\chi^{j\to a})(Z^{a\to i})^m$$
$$\times \delta[\psi^{a\to i} - F_\psi(\{\chi^{j\to a}_{j\in\partial a\setminus i}\})], \tag{14.10}$$
$$P^{i\to a}(\chi^{i\to a}) = \frac{1}{\mathcal{Z}^{i\to a}} \int \prod_{b\in\partial i\setminus a} dP^{b\to j}(\psi^{b\to j})(Z^{i\to a})^m$$
$$\times \delta[\chi^{i\to a} - F_\chi(\{\psi^{b\to i}_{b\in\partial i\setminus a}\})]. \tag{14.11}$$

消息现在是原 BP 消息上的概率分布。仍需求其不动点；对单张图数值求解很费力，因为每条边要更新一个完整概率分布，实际上是两个。

对于没有额外无序的随机正则图，例如随机正则图着色，正确解往往不依赖具体边 (ia)。每条边具有同一概率分布，可自然地用群体动力学求不动点：以大量样本表示分布，重加权因子 $(Z^{i\to a})^m$ 或 $(Z^{a\to i})^m$ 正比于每个元素在群体中出现的概率。

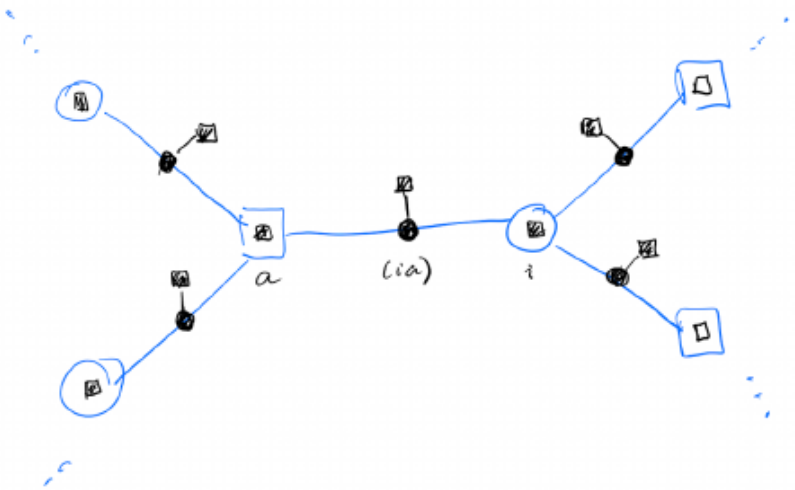


图 14.2.1: 从原因子图构造、用于分析 BP 不动点的辅助图模型。保留源物理页 228 的手绘因子图；蓝色节点为原节点，原边上的成对消息作为辅助变量。

由不动点，按辅助问题的 Bethe 熵公式计算副本自由熵：

$$N\Psi(m) = \sum_i \Phi^i + \sum_a \Phi^a - \sum_{ia} \Phi^{ia}, \tag{14.12}$$

其中

$$e^{m\Phi^i} = \int \prod_{a\in\partial i} dP^{a\to i}(\psi^{a\to i})(Z^i)^m, \tag{14.13}$$

$$e^{m\Phi^a} = \int \prod_{i\in\partial a} dP^{i\to a}(\chi^{i\to a})(Z^a)^m, \tag{14.14}$$

$$e^{m\Phi^{ia}} = \int dP^{a\to i}(\psi^{a\to i}) dP^{i\to a}(\chi^{i\to a})(Z^{ia})^m. \tag{14.15}$$

再由 $\Psi(m)$ 的 Legendre 变换得到曲线 $\Sigma(\Phi)$。

簇也可能进一步聚成超簇，或分裂成小簇，这会产生二步副本对称性破缺。还可继续考虑 K 步 RSB；需要无限层级时称为完全 RSB。作者指出，当时尚不知如何在随机稀疏图上求解完全 RSB 方程，而稠密优化问题中可以做到；这超出本讲范围。**译注：** 式 (14.8)–(14.9) 保留源文两个连续编号。用连续 δ 约束直接计数不动点的写法没有在此说明 Jacobian 等条件。式 (14.11) 的 $b \to j$ 与后面的 $b \to i$、(14.12) 与 $e^{m\Phi}$ 定义的 m 因子约定均保留，不自行补改。“当时尚不知” 指原讲义时间，未作为当前文献检索结论。

14.3　计算可着色阈值

用于给成簇阈值作上界的冻结变量概念，能大幅简化可着色阈值 c_{col} 的计算。仍限制于随机 d 正则图。解空间分簇，其中有些簇具有冻结变量。

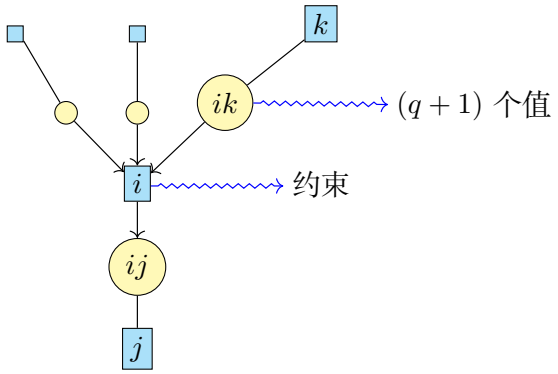
原文指出，平均度无穷小增加时，簇要消失就需要冻结变量：新加边会以高概率造成矛盾。冻结变量的比例也不能极小，因为它们必须形成相互支撑的骨架。因此假设，可着色阈值是全

部冻结簇消失时的平均度。簇对应 BP 不动点，于是计数冻结簇转化为计数具有冻结变量的 BP 不动点。

关键思想仍是把 BP 不动点条件视为新变量上的新约束，构造局部树状辅助图模型，再次用 BP 求解，并由自由熵计数冻结簇。这种“对冻结 BP 不动点做 BP”称为调查传播。

冻结消息的结构是：q 种颜色之一 s 对应 $\chi_{s_j}^{j\to i}=\delta_{s_j,s}=$“$s$”；非冻结消息 $\chi_{s_j}^{j\to i}=$其他形式 $=$“$*$”，称为“百搭”（joker）。每条边的每个方向，要么百搭，要么冻结为某个实际颜色。令边变量 $\nu_{ij}\in\{*,1,\dots,q\}$，共有 $q+1$ 个状态。新模型中，BP 方程成为约束，Bethe 熵各项成为因子权重，BP 消息成为变量；新消息是原消息上的概率分布。

下面讨论位于原节点位置的约束因子，类似图匹配问题。**译注：**源句字面为“Let us not discuss”；这里依后续展开将其按“now”译作“下面讨论”，仅是译者的上下文判断，不认定作者意图。



图示说明：依据源物理页 230 用 `tikz-cd` 重建；保留节点、ik/ij 边变量、指向 i 的箭头和两项蓝色标注。

节点 i 上的约束 $\mathcal{C}_i$ 要求：

- 若入值 $\nu_{ki}=s$，邻居 k 冻结于 s，因此出值 ν_{ij} 不能为 s；若 $\nu_{ki}=*$，则不约束 ν_{ij}。
- 入值不能禁止全部颜色。
- 若 $\nu_{ij}=*$，入边至少留下两种未禁止颜色；若 $v_{ij}=s$，则只有 s 未被禁止。

调查传播就是此新模型上关于 ν_{ij} 的 BP：

$$n_{\nu_{ij}}^{i\to j}=\frac{1}{Z^{i\to j}}\sum_{\{\nu_{ki}\}_{k\in\partial i\setminus j}}\mathcal{C}(\nu_{ij},\{\nu_{ki}\}_{k\in\partial i\setminus j})\prod_{k\in\partial i\setminus j}n_{\nu_{ki}}^{k\to j}.$$

用上述约束的具体形式和容斥原理，可使 SP 方程更明确。

- 当 $\nu_{ij}\neq *$：

$$\begin{aligned}n_{\nu_{ij}}^{i\to j}&=\frac{1}{Z^{i\to j}}\left\{\underbrace{\prod_{k\in\partial i\setminus j}(1-n_{\nu_{ij}}^{k\to i})}_{\text{邻居不禁止}\nu_{ij}}+\text{修正也允许}p\neq\nu_{ij}\text{ 的情形}\right\}\\&=\frac{1}{Z^{i\to j}}\left\{\prod_{k\in\partial i\setminus j}(1-n_{\nu_{ij}}^{k\to i})\right.\end{aligned}$$

$$
\begin{aligned}
&- \sum_{p\neq\nu_{ij}} \prod_{k\in\partial i\backslash j} (1-n_{\nu_{ij}}^{k\to i}-n_p^{k\to i}) + \cdots \\
&- (-1)^q \underbrace{\prod_{k\in\partial i\backslash j}\left(1-\sum_{p=1}^{q} n_p^{k\to i}\right)}_{\text{没有颜色被禁止}} \Bigg\} \\
&= \frac{1}{Z^{i\to j}} \sum_{l=0}^{q-1} (-1)^l \sum_{\substack{V\subseteq\{1,\dots,q\}\backslash\nu_{ij}\\ |V|=l}} \prod_{k\in\partial i\backslash j}\left(1-n_{\nu_{ij}}^{k\to i}-\sum_{v\in V} n_v^{k\to i}\right).
\end{aligned}
$$

- 当 $\nu_{ij}=*$:

$$
\begin{aligned}
n_*^{i\to j} &= \frac{1}{Z^{i\to j}}\{\text{至少有两种颜色未被禁止}\} \\
&= \frac{1}{Z^{i\to j}} \sum_{l=2}^{q} (-1)^l \sum_{\substack{V\subseteq\{1,\dots,q\}\backslash\nu_{ij}\\ |V|=l}} \prod_{k\in\partial i\backslash j}\left(1-\sum_{v\in V} n_v^{k\to i}\right).
\end{aligned}
$$

- 由归一化，$n_*^{i\to j}+\sum_{p=1}^{q} n_p^{i\to j}=1$，故

$$
\begin{aligned}
Z^{i\to j} &= \Pr(\text{没有矛盾，即至少一种颜色未被禁止}) \\
&= \sum_{p=1}^{q} \prod_{k\in\partial i\backslash j} (1-n_p^{k\to i}) - \sum_{p<r} \prod_{k\in\partial i\backslash j} (1-n_p^{k\to i}-n_r^{k\to i}) \\
&\quad + \cdots - (-1)^q \prod_{k\in\partial i\backslash j}\left(1-\sum_{p=1}^{q} n_p^{k\to i}\right) \\
&= \sum_{l=1}^{q} (-1)^{l-1} \sum_{\substack{V\subseteq\{1,\dots,q\}\\ |V|=l}} \prod_{k\in\partial i\backslash j}\left(1-\sum_{v\in V} n_v^{k\to i}\right).
\end{aligned}
$$

该问题的 Bethe 自由熵就是计数全部冻结簇的复杂度 Σ。上一节的复杂度则是包含典型解的簇的复杂度，二者关系下一讲讨论。由 SP 不动点按通常 Bethe 自由熵公式求得

$$
\begin{aligned}
\Sigma &= \frac{1}{N}\sum_{i=1}^{N} \log \Sigma^{(i)} - \frac{1}{N}\sum_{(ij)\in E} \log \Sigma^{(ij)}, \\
\Sigma^{(i)} &= \sum_{l=1}^{q} (-1)^{l-1} \sum_{\substack{V\subseteq\{1,\dots,q\}\\ |V|=l}} \prod_{k\in\partial i}\left(1-\sum_{v\in V} n_v^{k\to i}\right), \\
\Sigma^{(ij)} &= 1-\sum_{p=1}^{q} n_p^{i\to j} n_p^{j\to i}.
\end{aligned}
$$

$\Sigma^{(i)}$ 对应不排除节点 j 的消息归一化；$\Sigma^{(ij)}$ 是一条边两方向消息相容的概率，即不在两端强制同一种颜色。

在 d 正则图上，假设颜色对称（$n_p=\eta$，$p=1,\dots,q$），便得到关于可着色阈值的一个非常具体的猜想:

$$
\eta = \frac{\sum_{\ell=1}^{q}(-1)^{\ell-1}\binom{q-1}{\ell-1}(1-\ell\eta)^{d-1}}{\sum_{\ell=1}^{q}(-1)^{\ell-1}\binom{q}{\ell}(1-\ell\eta)^{d-1}},
$$

$$\Sigma = \log\left\{\sum_{\ell=1}^{q}(-1)^{\ell-1}\binom{q}{\ell}(1-\ell\eta)^{d}\right\} - \frac{d}{2}\log(1-q\eta^{2}).$$

先求 η 的不动点，再代入得到复杂度。若 $\Sigma > 0$，原文据上述猜想认为，大 N 随机 d 正则图以高概率可着色；反之不可着色。度数涨落的随机图公式略复杂，但推导思想完全相同。

现在，除 $c_c < c < c_{\mathrm{col}}$ 外，整个平均度范围已得到描述。尚余的凝聚相具有特殊性质，下一讲讨论。**译注：** 原通用 SP 式的 $k \to j$、约束中的 v_{ij}/ν_{ij} 混用照录。百搭分支的容斥系数及集合中减去 $\nu_{ij} = *$ 的写法、冻结颜色分支展开的末项符号按源保留；未以已知 SP 形式替换。原文从冻结簇消失定位可着色阈值的假设及颜色对称闭合均保留猜想地位，未称为已证随机图可着色阈值。

14.4 习题

习题 14.1：随机子立方体模型。模型由解空间 $S \subset \{0,1\}^N$ 定义，而非图模型。令 S 为 $\lfloor 2^{(1-\alpha)N} \rfloor$ 个随机簇的并，$\lfloor x \rfloor$ 表示取整数部分。随机簇 A 定义为

$$A = \{\sigma \mid \sigma_i \in \pi_i^A,\ \forall i \in \{1,\dots,N\}\}, \tag{14.16}$$

其中 π^A 为随机映射

$$\pi^A : \{1,\dots,N\} \longrightarrow \{\{0\},\{1\},\{0,1\}\},$$
$$i \longmapsto \pi_i^A.$$

对每个变量 i，π_i^A 以概率 $p/2$ 为 $\{0\}$，以概率 $p/2$ 为 $\{1\}$，以概率 $1-p$ 为 $\{0,1\}$。所以簇是 $\{0,1\}$ 的随机子立方体。若 $\pi_i^A = \{0\}$ 或 $\{1\}$，称 i 在 A 中“冻结”；否则称“自由”。给定构型 σ 可属于零个、一个或多个簇；“解”属于至少一个簇。

分析 $N \to \infty$ 极限，参数 α, p 固定且不依赖 N。簇 A 的内部熵定义为 $s = N^{-1}\log_2|A|$，即自由变量比例。$\Sigma(s)$ 定义为内部熵为 s 的簇数的以 2 为底对数，再除以 N。

(a) 模型中可满足阈值 α_s 的对应量是什么？

(b) 计算阈值 α_d，使低于该阈值时，大多数构型属于至少一个簇。

(c) 对 $\alpha > \alpha_d$，以 p, α 写出 $\Sigma(s)$。求总熵 $s_{\mathrm{tot}} = \max_s[\Sigma(s) + s \mid \Sigma(s) \geq 0]$。注意 $\alpha \in (\alpha_d, 1)$ 有两个区域，讨论其性质并给出“凝聚”阈值 α_c。

译注： 原文称簇为 $\{0,1\}$ 的子立方体，环境实际上是前面给出的 N 维超立方体；未改动原模型定义和习题要求。

15 副本对称性破缺：随机能量模型

如果你无法解决一个问题，那么必有一个更容易、而你能解决的问题：把它找出来。

George Pólya，《怎样解题》，1945

本章回到副本法，着重讨论最简单的一步副本对称性破缺（1RSB），并与空腔法中的 1RSB 联系起来。

为此，讨论 Bernard Derrida 于 1980 年为理解自旋玻璃和副本法提出的一个极简单模型。它既是理解关键概念的良好玩具模型，本身也很重要，与去噪和信息论中的重要概念相连。

随机能量模型是一个含 N 个变量的平凡自旋模型：$M = 2^N$ 个可能构型的能量，从高斯分布随机抽取后固定不变。正式地，随机能量模型（REM）有 2^N 个构型，其固定随机能量 E_i 抽自

$$P(E) = \mathcal{N}\left(0, \frac{N}{2}\right) = \frac{1}{\sqrt{\pi N}} e^{-E^2/N}. \tag{15.1}$$

配分和为

$$Z_N = \sum_{i=1}^{2^N} e^{-\beta E_i}. \tag{15.2}$$

15.1 严格解

先不使用副本法，计算模型的精确渐近解。为此，证明作为能量函数的 Boltzmann 熵密度，具有可计算的确定性渐近极限。

随机抽取 2^N 个能量后，有多少个落入 $[Ne, N(e+de)]$？将其记为 $\#(E)$。它依赖具体抽样，但可计算均值与方差。de 足够小时，

$$\begin{aligned} \mathbb{E}(\#Ne) &= 2^N \mathbb{E}[\mathbf{1}(E \in [Ne, N(e+de)])] \\ &\approx \frac{2^N}{\sqrt{\pi N}} e^{-Ne^2} de = \frac{1}{\sqrt{\pi N}} e^{-N(e^2 - \log 2)} de. \end{aligned} \tag{15.3}$$

由于从 $P(E)$ 抽到 e 与 $e+de$ 之间能量的概率很小，原文说计数服从 Poisson 分布，方差等于均值。定义 $s_{\text{ann}}(e) = \log 2 - e^2$，物理学称为退火熵密度，分两种情形。

- $s_{\text{ann}}(e) < 0$ 时，平均构型数指数趋于零，发生于 $e < -\sqrt{\log 2}$ 和 $e > \sqrt{\log 2}$。Markov 不等式[10] 说明，以高概率实际构型数也为零。具体地，

  $$\mathbb{P}(X \geq 1) \leq \mathbb{E}(X). \tag{15.4}$$

  因此，$N \to \infty$ 时，以高概率所有构型的能量密度均在 $[-\sqrt{\log 2}, \sqrt{\log 2}]$ 之间。

- $s_{\text{ann}}(e) > 0$ 时，有指数多个构型，方差也呈指数增长。然而，熵密度集中于确定值。再次使用 Markov 不等式和方差等于均值，

  $$\begin{aligned} \mathbb{P}\left(\left|\frac{\#(e)}{\mathbb{E}\#(e)} - 1\right| \geq k\right) &= \mathbb{P}\left(\left(\frac{\#(e)}{\mathbb{E}\#(e)} - 1\right)^2 \geq k^2\right) \\ &\leq \frac{\mathbb{E}[(\#(e) - \mathbb{E}[\#(e)])^2]}{k^2 (\mathbb{E}[\#(e)])^2} \\ &\leq \frac{\mathrm{Var}[\#(e)]}{k^2(\mathbb{E}[\#(e)])^2} \simeq \frac{\mathbb{E}[\#(e)]}{k^2(\mathbb{E}[\#(e)])^2} \propto \frac{e^{-N s_{\text{ann}}(e)}}{k^2}. \end{aligned} \tag{15.5}$$

  这里仍利用稀有能量事件的 Poisson 计数说明。若 $s_{\text{ann}}(e) > 0$，偏离概率随 N 指数趋零，因此以高概率 $\#(e)/\mathbb{E}\#(e)$ 任意接近 1。

[10] 若 X 为非负随机变量，则 $\mathbb{P}(X \geq k) \leq \mathbb{E}[X]/k$。此为原文页边说明，移作脚注保留。

由这种强集中，构型数在 $s(E) < 0$ 时为零，否则接近 $e^{N s_{\mathrm{ann}}(e)}$。熵密度写为

$$s(e) := \begin{cases} s_{\mathrm{ann}}(e), & s_{\mathrm{ann}}(e) \geq 0, \\ -\infty, & \text{其他情形.} \end{cases} \tag{15.6}$$

译注：式 (15.3) 的区间宽度为 Nde，原式前因子却写 $de/\sqrt{\pi N}$，未自行改动。有限独立样本的计数本为二项分布，Poisson 为稀有事件近似；方差与均值的精确关系和能量边缘的细尺度，不能由该简写无条件替代。主导指数熵的结论与这些有限尺度问题应区分。

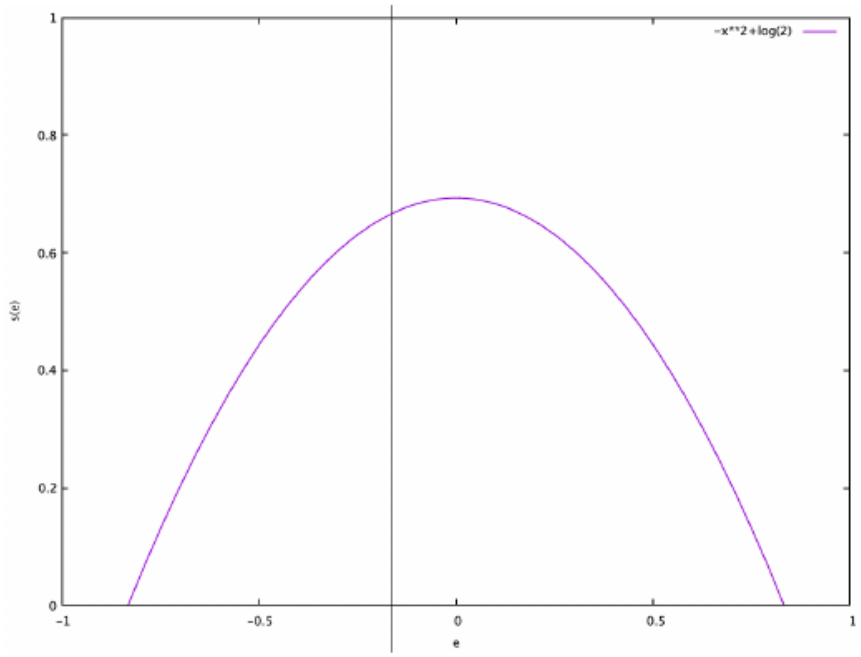


图 15.1.1: REM 中的熵密度，横轴为能量密度 e，纵轴为 $s(e)$。原图裁自源物理页 237。

无需无序平均，现在便可求解 REM。以高概率有

$$Z_N = \sum_E \#(E) e^{-\beta E} \approx \int_{-\sqrt{\log 2}}^{\sqrt{\log 2}} de\, e^{-N(\beta e - s(e))}. \tag{15.7}$$

用 Laplace 方法，求和由最大项主导，自由熵是熵的 Legendre 变换：

$$\lim_{N\to\infty} \frac{1}{N} \log Z = s(e^*) - \beta e^*, \tag{15.8}$$

$$e^* = \min_{[-\sqrt{\log 2}, \sqrt{\log 2}]} [\beta e - s(e)]. \tag{15.9}$$

再次有两种情况。极小值可由导数为零取得：

$$\beta = \partial_e s(e) = -2e. \tag{15.10}$$

但这只在 $s(e) > 0$ 时可行。$e = -\sqrt{\log 2}$ 时，$s(e) = 0$，且 $s'(e) = 2\sqrt{\log 2}$。故内部极小值仅适用于 $\beta < \beta_c = 2\sqrt{\log 2}$，此后 $e^* = -\sqrt{\log 2}$。于是

$$\lim_{N\to\infty} \frac{1}{N} \log Z = -(e^*)^2 + \log 2 - \beta e^* = \log 2 + \frac{\beta^2}{4}, \qquad \beta < \beta_c = 2\sqrt{\log 2}, \tag{15.11}$$

$$\lim_{N\to\infty}\frac{1}{N}\log Z=\beta\sqrt{\log 2},\qquad\qquad \beta\geq\beta_c=2\sqrt{\log 2}. \tag{15.12}$$

β_c 处的相变称为凝聚相变，因为概率测度凝聚于能量为 $-N\sqrt{\log 2}$ 附近的最低能构型。这对理解 1RSB 相变至关重要。**译注：**式 (15.9) 原文写 min 而非极小点 argmin，按源保留；最低能量处的描述按热力学主导阶理解。

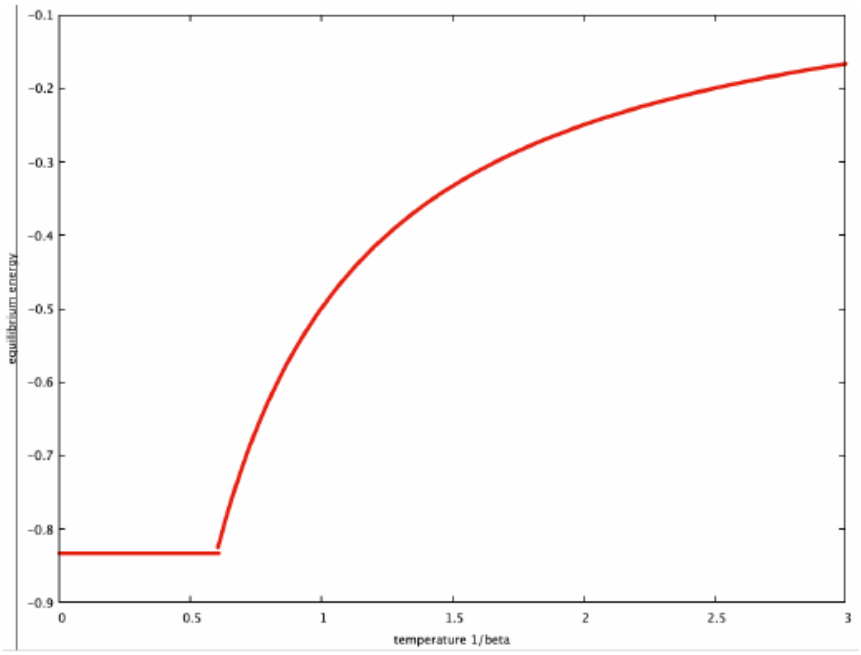


图 15.1.2: REM 中的平衡能量，横轴为温度 $1/\beta$，纵轴为平衡能量密度。原图裁自源物理页 238。

15.2 副本法求解

从复制的配分和开始：

$$Z^n=\prod_n\left(\sum_{i=1}^{2^N}e^{-\beta E_i}\right). \tag{15.13}$$

作看似平凡的改写：

$$Z^n=\sum_{i_1,\ldots,i_n=1}^{2^N}e^{-\beta(E_{i_1}+\cdots+E_{i_n})}, \tag{15.14}$$

$$=\sum_{i_1,\ldots,i_n=1}^{2^N}e^{-\beta\sum_{a=1}^n E_{i_a}}=\sum_{i_1,\ldots,i_n=1}^{2^N}e^{-\beta\sum_{a=1}^n(\sum_{j=1}^{2^N}E_j\mathbf{1}(j=i_a))}, \tag{15.15}$$

$$=\sum_{i_1,\ldots,i_n=1}^{2^N}\prod_{j=1}^{2^N}e^{-\beta E_j(\sum_{a=1}^n\mathbf{1}(j=i_a))}. \tag{15.16}$$

现在做无序平均。期望线性性使平均可移入求和，各 E_j 独立使平均可分别移入乘积。利用高斯积分[11]，

$$\begin{aligned}\mathbb{E}_{E_j} e^{-\beta E_j(\sum_{a=1}^n \mathbf{1}(j=i_a))} &= e^{N\beta^2(\sum_{a=1}^n \mathbf{1}(j=i_a))^2/4} \\ &= e^{N\beta^2 \sum_{a,b=1}^n \mathbf{1}(j=i_a)\mathbf{1}(j=i_b)/4}.\end{aligned} \tag{15.17}$$

故

$$\mathbb{E}[Z^n] = \sum_{i_1,\dots,i_n=1}^{2^N} e^{N\beta^2 \sum_{a,b=1}^n \mathbf{1}(i_a=i_b)/4}. \tag{15.18}$$

对副本构型 $(i_1,\dots,i_n)$ 引入 $n\times n$ 重叠矩阵 $Q_{ab}=\mathbf{1}(i_a=i_b)$，两个副本构型不同为 0，相同为 1。可写为

$$\mathbb{E}[Z^n] = \sum_{i_\alpha=1,\dots,i_n}^{2^N} e^{N\beta^2 \sum_{a,b=1}^n Q_{a,b}/4} = \sum_{\{Q\}} \#(Q) e^{N\beta^2 \sum_{a,b=1}^n Q_{a,b}/4}. \tag{15.19}$$

其中 $\sum_{\{Q\}}$ 遍历所有可能的此类矩阵，$\#(Q)$ 为产生该重叠矩阵的构型数。

15.2.1 一个有启发的界

暂取整数 n，可给所有 Z 的矩作一个有启发的界。所有 n 个副本在同一构型时，$Q_{a,b}=1$。原文称有 2^N 个这样的矩阵，因此

$$\mathbb{E}Z^n > 2^N e^{N\beta^2 n^2/4} > e^{N\beta^2 n^2/4}. \tag{15.20}$$

所以严格知道，Z 的矩至少按 e^{n^2} 增长。这是坏消息：若矩的增长不快于指数，根据 Carleman 条件，它们可完全确定 Z 的分布，进而确定其对数期望。本例增长更快，因此矩未必确定分布，$n<1$ 的解析延拓尤其未必唯一，需要选择“正确”延拓。这正是副本法的核心。Parisi 拟设给出一类明确的解析延拓，结果恰为正确选择。**译注：**全 1 重叠矩阵只有一个，2^N 计数的是其构型赋值。整数 $n=1$ 时上述首个严格大于号可变成等号；源式符号照录。快速矩增长使通常的充分判据不能直接用，但仅凭该下界不能证明矩问题不唯一或任意延拓无效。

15.2.2 副本对称解

尝试 $n\to 0$ 的解析延拓。先取整数 n，对固定重叠矩阵预期构型数为指数级，记 $\#(Q)=e^{Ns_q(Q)}$，则

$$\mathbb{E}Z^n \approx \int dQ\, e^{N(\frac{\beta^2}{4}\sum_{a,b=1}^n Q_{a,b}+s_q(Q))} =: \int dQ\, e^{Ng(\beta,Q)}. \tag{15.21}$$

大 N 时，选择主导求和的“正确” Q 结构作 Laplace / 鞍点近似。自然的拟设是所有副本等同，系统在重新标记副本下不变，即具有置换对称性。Q 只有两种选择：全为 1，或对角为 1、非对角为 0，二者的 $s_q(Q)$ 均易求。

1. 若 $Q_{ab}=1$，所有副本位于同一构型，$\mathcal{N}=2^N$，$g(\beta,Q)=n^2\beta^2/4+\log 2$。这没有关于 n 的线性部分所需的极限，无法用于副本法，是错误的解析延拓。

[11]若 X 为零均值、方差 Δ 的高斯变量，则 $\mathbb{E}[e^{bX}]=e^{b^2\Delta/2}$。原文页边说明移作脚注。

2. 若 $Q_{aa}=1$、$Q_{ab}=0$（$a\neq b$），所有副本构型互异，$\#(Q)=2^N(2^N-1)\cdots(2^N-n+1)$，$n\ll N$ 时 $s(Q)\approx n\log 2$，故 $g(\beta,Q)=n\beta^2/4+n\log 2$。

副本对称层次给出所有温度下的自由熵

$$f_{\mathrm{RS}}(\beta)=\beta^2/4+\log 2. \tag{15.22}$$

它在 $\beta<\beta_c$ 时正确，$\beta>\beta_c$ 时则显然错误。

15.2.3 副本对称性破缺解

遵循 Parisi，改用另一鞍点拟设：将 n 个副本分成每组 m 个的 n/m 组，组内重叠为 1、组间为 0。每组可选一个构型，计数为

$$\mathcal{N}=2^N(2^N-1)\cdots(2^N-n/m+1),$$
$$s_q(Q)=\frac{\log(2^N)^{n/m}}{N}=\frac{n}{m}\log 2,\qquad \sum_{a,b}Q_{a,b}=\frac{n^2}{n/m}=nm.$$

因此

$$\mathbb{E}[Z^n]\simeq e^{N[\frac{n}{m}\log 2+\frac{\beta^2}{4}nm]}, \tag{15.23}$$
$$g(q)=nm\beta^2/4+(n/m)\log 2,\qquad 1\le m\le n. \tag{15.24}$$

$n\to 0$ 时极限良好，得到

$$f_{\mathrm{1RSB}}(\beta,m)=m\beta^2/4+(\log 2)/m. \tag{15.25}$$

现在选择 m。Parisi 最初的推理几乎像个玩笑：整数 n 时显然 $n\ge m\ge 1$，而 $n\to 0$ 后要求 $n\le m\le 1$；同时对应的还是极小值而非极大值！后面借助空腔法解释，暂且遵循其处方。对 m 取极值得

$$\beta^2/4=(\log 2)/m^2, \tag{15.26}$$
$$m=\min[\beta_c/\beta,1]. \tag{15.27}$$

未截断时 $m=\beta_c/\beta$，再用 $m\le 1$ 得到第二式。结果恰为正确解：

1. $\beta<\beta_c$（高温），$m=1$，

$$f_{\mathrm{1RSB}}(\beta,m)=\beta^2/4+\log 2=f_{\mathrm{RS}}(\beta,m). \tag{15.28}$$

2. $\beta>\beta_c$（低温），$m=\beta_c/\beta$，

$$f_{\mathrm{1RSB}}(\beta,m)=\beta_c\beta/4+\beta\log 2/\beta_c=\beta\sqrt{\log 2}. \tag{15.29}$$

这确实是正确的自由能。方法看似神奇，却行得通。**译注：**本节 $g(q)/g(\beta,Q)$、$f_{\mathrm{RS}}(\beta,m)$、“自由能 / 自由熵” 等原文记法保持。整数副本的分组计数与 $n\to 0$ 的延拓处方是不同层次，并未因复现正确 REM 结果就证明一般副本延拓的合法性。

15.2.4 凝聚相变与参与比

副本法还能解释 β_c 处的相变性质。低温时，Boltzmann 测度凝聚于接近 $e=-\sqrt{\log 2}$ 的最低能级，但真正参与的构型有多少？可计算**参与比**

$$Y=\sum_{i=1}^{2^N}\left(\frac{e^{-\beta E_j}}{Z}\right)^2. \tag{15.30}$$

粗略而言，参与比是对求和起作用的构型数的倒数。用副本法计算其平均：

$$\begin{aligned}
\mathbb{E}Y &= \mathbb{E}\left[\sum_{i=1}^{2^N}\left(\frac{e^{-\beta E_j}}{Z}\right)^2\right]=\mathbb{E}\left[\frac{1}{Z^2}\sum_{i=1}^{2^N}e^{-2\beta j}\right]\\
&=\lim_{n\to 0}\mathbb{E}\left[Z^{n-2}\sum_{i=1}^{2^N}e^{-2\beta E_j}\right], &(15.31)\\
&=\lim_{n\to 0}\mathbb{E}\left[\sum_{i_1,\dots,i_{n-2}}e^{-\beta(E_{i_1}+\cdots+E_{i_{n-2}})}\sum_{i=1}^{2^N}e^{-2\beta E_j}\right], &(15.32)\\
&=\lim_{n\to 0}\mathbb{E}\left[\sum_{i_1,\dots,i_n}e^{-\beta(E_{i_1}+\cdots+E_{i_n})}\mathbf{1}(i_{n-1}=i_n)\right]. &(15.33)
\end{aligned}$$

利用各副本的置换不变性，对称化得

$$\mathbb{E}Y=\lim_{n\to 0}\frac{1}{n(n-1)}\sum_{a\neq b}\mathbb{E}\left[\sum_{i_1,\dots,i_n}e^{-\beta(E_{i_1}+\cdots+E_{i_n})}\mathbf{1}(i_a=i_b)\right]. \tag{15.34}$$

由于 $Z^n\to 1$，可以写为

$$\begin{aligned}
\mathbb{E}Y &=\lim_{n\to 0}\frac{1}{n(n-1)}\sum_{a\neq b}\frac{\mathbb{E}[\sum_{i_1,\dots,i_n}e^{-\beta(E_{i_1}+\cdots+E_{i_n})}\mathbf{1}(i_a=i_b)]}{\mathbb{E}[\sum_{i_1,\dots,i_n}e^{-\beta(E_{i_1}+\cdots+E_{i_n})}]}, &(15.35)\\
&=\lim_{n\to 0}\frac{1}{n(n-1)}\langle Q_{a,b}\rangle. &(15.36)
\end{aligned}$$

再假设副本计算由 1RSB 鞍点主导，

$$\begin{aligned}
\mathbb{E}Y &=\lim_{n\to 0}\frac{1}{n(n-1)}\sum_{a\neq b}Q_{a,b}^{\mathrm{1RSB}}, &(15.37)\\
&=\lim_{n\to 0}\frac{1}{n(n-1)}\frac{n}{m}[m^2-m]=\lim_{n\to 0}\frac{1}{n-1}[m-1], &(15.38)\\
&=1-m=1-\beta_c/\beta. &(15.39)
\end{aligned}$$

现在可以作图。原文说参与比在零温为 1，在 $T=T_c=1/\beta_c$ 发散。类似计算给出有限二阶矩，因此原文认为该数不自平均：参与的构型数随实例涨落。**译注：** 源式 (15.30)–(15.32) 的求和 i 与能量下标 j、(15.31) 中的 $e^{-2\beta j}$、(15.36) 中缺失的 $\sum_{a\neq b}$ 均保留。由式 (15.39) 可知 Y 在临界点趋于零，原图画的是其倒数，不是 Y 发散。二阶矩有限本身不足以推出不自平均，还须与一阶矩平方比较，见本章习题。

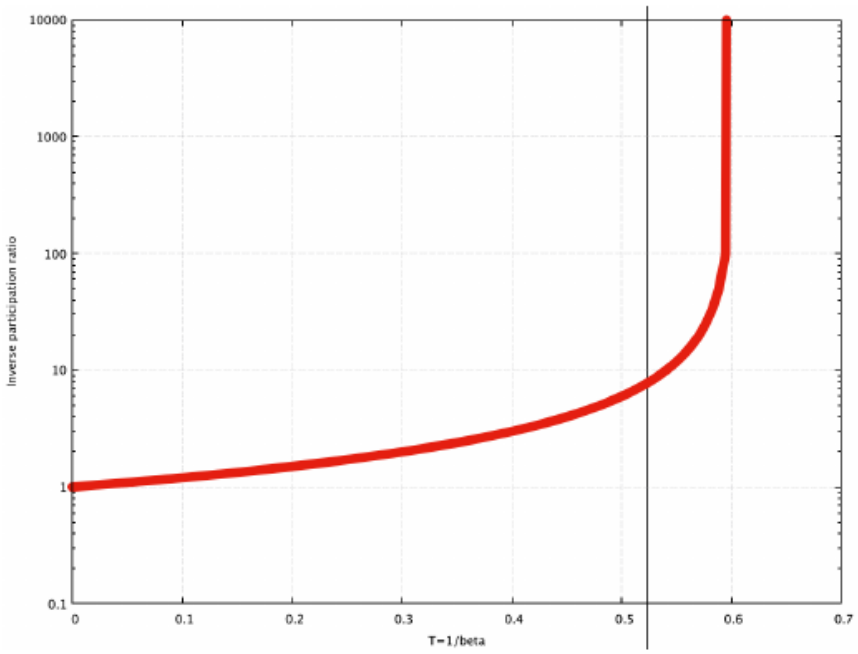


图 15.2.1: REM 的逆参与比。横轴为 $T = 1/\beta$，纵轴为逆参与比，采用对数刻度。原图裁自源物理页 242；保留原图所画量与正文参与比记号的区别。

15.2.5 重叠的分布

还可由可能重叠的分布理解副本解。取同一系统的两个独立真实副本，它们处于同一构型的概率是多少？等价地，重叠为 1 的概率是多少？这正是参与比：

$$\begin{aligned}\mathbb{E}[P(q=1)] &= \mathbb{E}\left[\sum_{i,j=1}^{2^N} \frac{e^{-\beta E_i-\beta E_j}}{Z^2}\mathbf{1}(i=j)\right] = \mathbb{E}[Y] \\ &= \lim_{n\to 0} \frac{\sum_{a\neq b}\mathbf{1}(Q_{a,b})}{n(n-1)}.\end{aligned} \tag{15.40}$$

高温 RS 解只有重叠 0：高温抽样的两个构型以高概率不同。低温 1RSB 解则以概率 $1-m$ 有 $q=1$、以概率 m 有 $q=0$；两个样本以概率 $1-m$ 完全相同。这是凝聚的另一种理解。自旋玻璃语言称重叠分布变得非平凡，从高温的单个 δ 峰

$$\mathbb{E}P_{\mathrm{RS}}(q) = \delta(q), \tag{15.41}$$

变为低温双峰分布

$$\mathbb{E}P_{\mathrm{1RSB}}(q) = (1-m)\delta(q-1) + m\delta(q). \tag{15.42}$$

15.3 副本势与复杂度的联系

副本法几乎能计算所有想要的量。如何把这里的 RSB 与空腔法中的 RSB 联系起来，同时解释奇怪的副本拟设和极小化处方？可以使用空腔法的构造。

1RSB 势。上一章的核心思想是，存在许多可计数的 “Gibbs 态”。总配分和可分为许多部分，每个部分定义一个 Gibbs 态，关心的量在态内定义良好并集中：

$$Z = \sum_{\alpha} Z_{\alpha}. \tag{15.43}$$

为计数这些态，引入将各配分和取 m 次幂的修正配分和：

$$Z(m) = \sum_{\alpha} Z_{\alpha}^{m} = \sum_{\alpha} e^{N m f_{\alpha}}, \tag{15.44}$$

其中 $f_{\alpha} = N^{-1} \log Z_{\alpha}$ 为每个态的自由熵。假设态有指数多个，将离散求和近似为积分，并希望所用近似（BP、RS 等）给出正确结果：

$$Z(m) = \int df \, \#(f) e^{N m f_{\alpha}} = \int df \, e^{N(m f_{\alpha} + \Sigma(f))}. \tag{15.45}$$

复杂度 $\Sigma(f)$ 是自由熵为 f 的态数的对数除以 N。接着作 Laplace 积分，原文再次写出

$$Z(m) = \int df \, \#(f) e^{N m f_{\alpha}} = \int df \, e^{N(m f_{\alpha} + \Sigma(f))}, \tag{15.46}$$

从而得到热力学势

$$\Psi(m) = \frac{1}{N} \log Z(m) \longrightarrow m f_{\alpha^*} + \Sigma(f^*), \tag{15.47}$$

$$m = - \left. \partial_f \Sigma(f) \right|_{f^*}. \tag{15.48}$$

这是空腔法 1RSB 的基础，并可计算复杂度函数。Legendre 变换还保证

$$\partial_m \Psi(m) = f^*. \tag{15.49}$$

如上一章所述，Σ 是真实态数对数的某种平均版本，可能为负，因此应只在满足 $\Sigma \geq 0$ 的 m 范围计算。

这类似 REM，只是 REM 中 “构型” 本身就是一个 “Gibbs 态”，因为模型很简单。最低能量构型上的凝聚仍发生，因此当 Σ 为负时，m 可以不等于 1。

用副本计算：“真实副本” 方法。能用副本法得到同一个 $\Psi(m)$ 吗？可以，而且很有启发。强制 m 个副本处于同一 “态”，则

$$Z^m = \left(\sum_{\alpha} Z_{\alpha} \right)^m = \sum_{i_1, i_2, \ldots, i_m} Z_{i_1} Z_{i_2} \cdots Z_{i_m}, \tag{15.50}$$

$$Z^m_{\text{constrained}} = \sum_{\alpha} Z_{\alpha}^m, \tag{15.51}$$

后式正是计算势所需的对象。再对其对数取平均，使用副本法写为

$$\Psi(m) = \mathbb{E} \frac{1}{N} \log Z^m_{\text{constrained}} = \lim_{n' \to \infty} \frac{(Z^m_{\text{constrained}})^{n'} - 1}{N n'}. \tag{15.52}$$

它给出复杂度的 Legendre 变换。另一方面，

$$\frac{1}{m} \mathbb{E} \frac{1}{N} \log Z^m_{\text{constrained}} = \lim_{n' \to 0} \frac{Z^{m n'}_{\text{constrained}} - 1}{N m n'}, \tag{15.53}$$

$$= \lim_{n\to 0} \frac{Z^n_{\text{constrained}} - 1}{Nn}, \tag{15.54}$$

$$\tag{15.55}$$

因此，约束 m 个副本处于同一 Gibbs 态的 1RSB 拟设，除了一个 $1/m$ 因子，正是在计算复杂度的 Legendre 变换；它是在副本空间构造 $\Psi(m)$ 的一种方式。

作者认为，这为 1RSB 拟设给出清楚得多的动机：除非复杂度为负，m 应为 1，因而 $m \in [0,1]$。它还解释了为何须对副本 1RSB 公式的 m 取极值：

$$\partial_m \frac{\Psi(m)}{m} = \frac{\Psi'(m)m - \Psi(m)}{m^2}, \tag{15.56}$$

导数为零时，

$$\Psi'(m)m - \Psi(m) = 0, \tag{15.57}$$

$$f^* m - f^* m + \Sigma(f^*) = 0, \tag{15.58}$$

$$\Sigma(f^*) = 0. \tag{15.59}$$

所以，副本形式中对 m 取极值，等同于寻找零复杂度，正是低温 REM 所需的操作。**译注：**式 (15.45)、(15.46) 为源文重复的编号式，保留 f/f_α 记法；原指数缺失的闭括号仅作排版配对。式 (15.52) 的 $n' \to \infty$、随后各式未显式出现的无序期望、(15.58) 的 $+\Sigma$ 均照源保留；按前式代入通常应出现 $-\Sigma$，但零复杂度结论不受这个整体符号差异影响。式 (15.55) 在源文中为空编号。端点 $m = 0$ 的含义须通过极限处理，不将形式处方当作一般解析延拓证明。

文献

Parisi 在一系列深刻论文（1979，1980）中提出副本对称性破缺，这最终使他获得 2021 年诺贝尔物理学奖。重叠分布由 Parisi（1983）引入，其在副本理论中的基本作用见 Mézard 等（1984）。Derrida（1980，1981）提出 REM 作为理解副本和自旋玻璃的玩具模型，它对澄清副本法起了重要作用，也推动了 Gross 与 Mézard（1984）对著名 p 自旋模型的研究。以 Gibbs 态计数为基础的构造见 Monasson（1995）、Mézard 与 Parisi（1999）；它对前章讨论的现代空腔法至关重要，参见 Mézard 与 Parisi（2001）、Mézard 等（2002）、Mézard 与 Parisi（2003）。

15.4 习题

习题 15.1：把 REM 看作 p 自旋模型。 p 自旋模型是自旋玻璃理论的基石之一。N 个自旋 $S_i = \pm 1$ 有 2^N 个构型，Hamiltonian 含所有可能的 p 体相互作用：

$$\mathcal{H} = -\sum_{i_1, i_2, \ldots, i_p} J_{i_1,\ldots,i_p} S_{i_1} \cdots S_{i_p}, \tag{15.60}$$

$$P(J) = \sqrt{\frac{\pi p!}{N^{p-1}}} e^{-N^{p-1}J^2/p!}. \tag{15.61}$$

1. 利用高斯积分计算配分函数的矩，证明

$$\mathbb{E}[Z^n] = \sum_{\{S_i^a\},\{S_i^b\},\ldots,\{S_i^n\}} \exp\left[\frac{\beta^2}{4N^{p-1}} \sum_{a,b} \left(\sum_i S_i^a S_i^b\right)^p\right]. \tag{15.62}$$

2. 引入固定重叠的 δ 函数并作 Fourier 变换，证明

$$\mathbb{E}[Z^n] \approx \int \prod_{a<b} dq_{a,b} d\widehat{q}_{a,b}\, e^{-NG(Q,\widehat{Q})}, \tag{15.63}$$

其中

$$G(Q,\widehat{Q}) = -n\frac{\beta^2}{4} - \frac{\beta^2}{2}\sum_{a<b} q_{a,b}^p + i\sum_{a<b}\widehat{q}_{a,b}q_{a,b} - \log\left[\sum_{\{S_i^a,\dots,S_i^n\}} e^{\sum_{a<b} i\widehat{q}_{a,b}\frac{1}{N}\sum_i S_i^a S_i^b}\right]. \tag{15.64}$$

3. 使用副本对称解，证明自由熵为

$$f_{\mathrm{RS}} = \frac{\beta^2}{4} + \log 2, \tag{15.65}$$

与 REM 相同。当然，也可破缺对称性得到低温正确的 1RSB 解，至少对足够大的 p 和一定温度范围如此。

4. 证明 $p \to \infty$ 时，各构型能量不再相关，p 自旋模型在该极限成为 REM。

译注： 式 (15.61) 的归一化因子、全指标求和与重复指标的约定，以及作用量 (15.64) 的 $1/N$ 位置均按原式保留。RS 表达式对应的分支和温度范围、有限 p 与 REM 的区别仍需相应拟设；$p \to \infty$ 的去相关还须区分不同构型及整体翻转等特殊重叠。

习题 15.2：REM 参与比的二阶矩。对 $\beta \geq \beta_c$，用副本法证明

$$\mathbb{E}[Y^2] = \frac{3 - 5m + 2m^2}{3}. \tag{15.66}$$

由此推出 Y 不自平均。原文指出，这些结果实际上不依赖 REM，而依赖 1RSB 结构，对所有 1RSB 模型普适。

习题 15.3：Ω 个高斯数的最大值与去噪。

- 给定 Ω 个独立同分布高斯数 $Z_i \sim \mathcal{N}(0,\Delta)$。用与 REM 相同的推理证明，$\log\Omega$ 很大时，$\omega_{\max} = \max_i Z_i/\sqrt{\log\Omega}$ 以高概率为 $\sqrt{2\Delta}$。对多个 Ω 数值计算最大值的平均，检验该预测。

- 考虑稀疏 Ω 维向量 x^*，只有少数（例如一两个）分量为 $O(1)$，其余为零。观测为 $y = x^* + z$，其中噪声各分量为独立方差 Δ 的高斯数。能提出简单算法，使 Ω 很大时以高概率从 y 恢复 x^* 吗？对什么 Δ 能奏效？用模拟检验。

译注： 最大值陈述为所示归一化下的渐近高概率极限；稀疏恢复题中的噪声尺度、信号幅度和恢复准则是判断可行范围的关键，不替原题补造肯定答案。参与比普适性保留作者所指 1RSB 结构的语境，未另行证明一般模型的同一公式。

第四部分：统计学与机器学习

16 线性估计与压缩感知

他并非为了赢来的钱，

也不是为了赢得尊重。

他发牌，是为寻找答案，

偶然之中神圣的几何，

可能结果后隐藏的规律。

Sting，《Shape of My Heart》，1993

16.1 问题陈述

观测 M 维向量 y_μ（$\mu = 1, \dots, M$），其分量由未知 N 维向量 x_i（$i = 1, \dots, N$）经已知矩阵 $F_{\mu i}$ 线性投影后得到：

$$y_\mu = f_{\text{out}}\left(\sum_{i=1}^{N} F_{\mu i} x_i \right). \tag{16.1}$$

输出函数 f_{out} 包含噪声。例如，加性白高斯噪声（AWGN）为 $f_{\text{out}}(x) = x + \xi$，$\xi$ 是随机高斯变量；线性阈值输出为 $f_{\text{out}}(x) = \operatorname{sign}(x - \kappa)$，$\kappa$ 是阈值。线性估计的目标是由 y, F, f_{out} 推断 x。另一种表述是令 $z_\mu = \sum_{i=1}^{N} F_{\mu i} x_i$，考虑给定 z 的观测似然

$$P(y \mid z) = \prod_{\mu=1}^{M} P_{\text{out}}(y_\mu \mid z_\mu). \tag{16.2}$$

16.2 松弛信念传播

介绍理解算法来源所需的主要步骤。后验分布为

$$P(x \mid y, F) = \frac{1}{Z} \prod_{\mu=1}^{M} P_{\text{out}}(y_\mu \mid z_\mu) \prod_{i=1}^{N} P_X(x_i), \qquad z_\mu = \sum_{i=1}^{N} F_{\mu i} x_i. \tag{16.3}$$

$F_{\mu i}$ 的随机矩阵元独立，但不必同分布，均值与方差均为 $O(1/N)$。此后验对应测量 y_μ 在变量（自旋）x_i 间产生的相互作用图，见图 16.2.1。

AMP 推导从该图模型的 BP 开始。$F_{\mu i}$ 为随机淬火无序，y_μ 为植入无序。原文认为，只要矩阵元独立且均值、方差为 $O(1/N)$，相应系统就是平均场自旋玻璃；贝叶斯最优时，即先验匹配信号的真实经验分布时，最低自由能 BP 不动点给出后验的渐近精确边缘。

BP 在变量圆节点与因子方节点间传递消息 $m_{i \to \mu}$ 及反向消息 $m_{\mu \to i}$，描述算法当前对 x_i 分布的“信念”：

$$m_{i \to \mu}(x_i) = \frac{1}{z_{i \to \mu}} P_X(x_i) \prod_{\gamma \neq \mu} m_{\gamma \to i}(x_i), \tag{16.4}$$

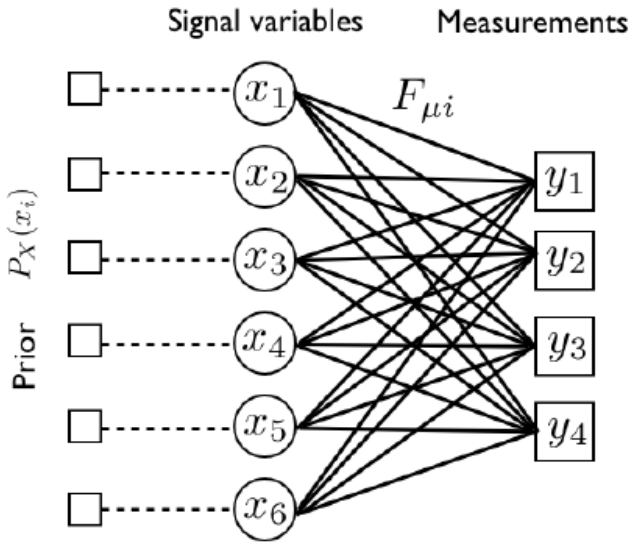


图 16.2.1: 广义线性估计后验对应的因子图。圆为未知变量，方框为变量间相互作用；上方两列分别为信号变量和测量，左侧为先验 $P_X(x_i)$，边权为 $F_{\mu i}$。原图裁自源物理页 250。

$$m_{\mu\to i}(x_i)=\frac{1}{z_{\mu\to i}}\int\prod_{j\neq i}[dx_j m_{j\to\mu}(x_j)]P_{\rm out}\left(y_\mu\mid\sum_l F_{\mu l}x_l\right). \tag{16.5}$$

虽容易写出，但每个相互作用涉及 N 个变量，需要 $(N-1)$ 重积分，计算上不可处理。变量还连续，消息为密度，数值处理也困难，原文引第 8 章。

中心极限定理和仅保留消息前两个矩的投影，使 BP 可处理；类似做法也用于高斯 BP 和非参数 BP。所得**松弛信念传播**（r-BP）对每个变量—相互作用对只保留均值与方差。

先看式 (16.5)，$z_\mu=F_{\mu i}x_i+\sum_{j\neq i}F_{\mu j}x_j$。该积分中各 x_j 独立，由中心极限定理，预期后一个和为高斯变量，其均值 $\omega_{\mu\to i}=\sum_{j\neq i}F_{\mu j}a_{j\to\mu}$，方差 $V_{\mu\to i}=\sum_{j\neq i}F_{\mu j}^2v_{j\to\mu}$，其中

$$a_{i\to\mu}\equiv\int dx_i\,x_i m_{i\to\mu}(x_i),\qquad v_{i\to\mu}\equiv\int dx_i\,x_i^2 m_{i\to\mu}(x_i)-a_{i\to\mu}^2. \tag{16.6}$$

多维积分便可换成对随机变量 z 的标量高斯积分：

$$m_{\mu\to i}(x_i)\propto\int dz_\mu\,P_{\rm out}(y_\mu\mid z_\mu)e^{-(z-\omega_{\mu\to i}-F_{\mu i}x_i)^2/(2V_{\mu\to i})}. \tag{16.7}$$

完整概率分布的复杂多维积分，变成只依赖前两个矩的标量积分。

还可进一步简化。原文先改写

$$(z-\omega_{\mu\to i}-F_{\mu i}x_i)^2=(z-\omega_{\mu\to i})^2+F_{\mu i}^2x_i^2-2(z-\omega_{\mu\to i})F_{\mu i}x_iF_{\mu i}x_i,$$

再用 $F_{\mu i}=O(1/\sqrt{N})$ 展开指数：

$$\begin{aligned}m_{\mu\to i}(x_i)\propto&\int dz_\mu\,P_{\rm out}(y_\mu\mid z_\mu)e^{-(z-\omega_{\mu\to i})^2/(2V_{\mu\to i})}\\&\times\Big(1+F_{\mu i}^2x_i^2-2(z-\omega_{\mu\to i})F_{\mu i}x_i\\&\qquad+\tfrac{1}{2}(z-\omega_{\mu\to i})^2F_{\mu i}^2x_i^2+o(1/N)\Big).\end{aligned} \tag{16.8}$$

引入由输出概率定义的函数

$$g_{\rm out}(\omega, y, V) \equiv \frac{\int dz\, P_{\rm out}(y \mid z)(z-\omega)e^{-(z-\omega)^2/(2V)}}{V\int dz\, P_{\rm out}(y \mid z)e^{-(z-\omega)^2/(2V)}}. \tag{16.9}$$

该测度下的二阶平均满足

$$\frac{\int dz\, P_{\rm out}(y \mid z)(z-\omega)^2 e^{-(z-\omega)^2/(2V)}}{V^2\int dz\, P_{\rm out}(y \mid z)e^{-(z-\omega)^2/(2V)}} = \frac{1}{V} + \partial_\omega g_{\rm out}(\omega, y, V) + g_{\rm out}^2(\omega, y, V). \tag{16.10}$$

使用式 (16.9)，将依赖 x_i 的项重新指数化并保留主导阶，归一化后得到式 (16.5) 的迭代形式：

$$m_{\mu\to i}(t, x_i) = \sqrt{\frac{A^t_{\mu\to i}}{2\pi N}}\exp\left[-\frac{x_i^2}{2N}A^t_{\mu\to i} + B^t_{\mu\to i}\frac{x_i}{\sqrt{N}} - \frac{(B^t_{\mu\to i})^2}{2A^t_{\mu\to i}}\right], \tag{16.11}$$

$$\tag{16.12}$$

其中

$$\begin{aligned} B^t_{\mu\to i} &= g_{\rm out}(\omega^t_{\mu\to i}, y_\mu, V^t_{\mu\to i})F_{\mu i}, \\ A^t_{\mu\to i} &= -\partial_\omega g_{\rm out}(\omega^t_{\mu\to i}, y_\mu, V^t_{\mu\to i})F^2_{\mu i}. \end{aligned}$$

指数为二次型，可写成高斯分布。将式 (16.4) 写为这些高斯与先验的乘积，即可闭合：

$$m_{i\to\mu}(x_i) \propto P_X(x_i)e^{-(x_i-R_{i\to\mu})^2/(2\Sigma_{i\to\mu})}. \tag{16.13}$$

记 $\partial_\omega, \partial_R$ 分别为对 ω, R 的偏导，定义输入函数

$$f_a(\Sigma, R) = \frac{\int dx\, xP_X(x)e^{-(x-R)^2/(2\Sigma)}}{\int dx\, P_X(x)e^{-(x-R)^2/(2\Sigma)}}, \qquad f_v(\Sigma, R) = \Sigma\partial_R f_a(\Sigma, R). \tag{16.14}$$

译注： 独立矩阵元及前两矩尺度本身不足以覆盖任意重尾系综、非匹配先验或所有 BP 不动点的精确性；沿用本章的渐近假设。源平方展开重复 $F_{\mu i}x_i$，式 (16.8) 缺相应 V 因子且系数可疑，(16.11) 的 N 缩放与随后 A, B 定义也需核对；均不静默修改。式 (16.12) 是原空编号，z/z_μ 记法保留。

算法 1：松弛信念传播（r-BP）

输入 y。初始化 $a_{i\to\mu}(t=0), v_{i\to\mu}(t=0)$，令 $t=1$。重复以下更新。

1. 更新 $\omega_{\mu\to i}, V_{\mu\to i}$：

$$V_{\mu\to i}(t) \leftarrow \sum_{j\neq i} F^2_{\mu j}v_{j\to\mu}(t-1), \tag{16.15}$$

$$\omega_{\mu\to i}(t) \leftarrow \sum_{j\neq i} F_{\mu j}a_{j\to\mu}(t-1). \tag{16.16}$$

2. 更新 $A_{\mu\to i}, B_{\mu\to i}$：

$$B_{\mu\to i}(t) \leftarrow g_{\rm out}(\omega_{\mu\to i}(t), y_\mu, V_{\mu\to i}(t))F_{\mu i}, \tag{16.17}$$

$$A_{\mu\to i}(t) \leftarrow -\partial_\omega g_{\rm out}(\omega_{\mu\to i}(t), y_\mu, V_{\mu\to i}(t))F^2_{\mu i}. \tag{16.18}$$

3. 更新 $R_{\mu\to i},\Sigma_{\mu\to i}$：

$$\Sigma_{i\to\mu}(t)\leftarrow\frac{1}{\sum_{\nu\neq\mu}A_{\nu\to i}(t)},\tag{16.19}$$

$$R_{i\to\mu}(t)\leftarrow\Sigma_{i\to\mu}(t)\sum_{\nu\neq\mu}B_{\nu\to i}(t).\tag{16.20}$$

4. 更新估计的部分边缘 $a_{i\to\mu}(t),v_{i\to\mu}(t)$：

$$a_{i\to\mu}\leftarrow f_a(\Sigma_{i\to\mu}(t),R_{i\to\mu}(t)),\tag{16.21}$$

$$v_{i\to\mu}\leftarrow f_v(\Sigma_{i\to\mu}(t),R_{i\to\mu}(t)).\tag{16.22}$$

令 $t\leftarrow t+1$，直至 $a_{i\to\mu}(t),v_{i\to\mu}(t)$ 收敛。输出估计边缘的均值和方差：

$$a_i\leftarrow f_a\left(\frac{1}{\sum_\nu A_{\nu\to i}},\frac{\sum_\nu B_{\nu\to i}}{\sum_\nu A_{\nu\to i}}\right),\tag{16.23}$$

$$v_i\leftarrow f_v\left(\frac{1}{\sum_\nu A_{\nu\to i}},\frac{\sum_\nu B_{\nu\to i}}{\sum_\nu A_{\nu\to i}}\right).\tag{16.24}$$

译注：原算法浮至源物理页 260，此处移到首次调用位置，编号及更新式保持；更新组标题原写 $\mu\to i$，其式实际为 $i\to\mu$，未替源文统一。

先验与输出的例子

r-BP 适用于元素间因子化的一般先验 P_X，以及逐元素的一般输出信道 P_{out}。具体形式仅通过式 (16.14) 的 f_a 和式 (16.9) 的 g_{out} 进入。下面给出例子。

概率压缩感知最常用的稀疏先验是高斯—Bernoulli 先验，即原文未解析引用 “(??)” 中 $\phi(x)=\mathcal{N}(\bar{x},\sigma)$，高斯均值为 $\bar{x}$，方差为 σ。其输入函数为

$$f_a^{\text{Gauss-Bernoulli}}(\Sigma,T)=\frac{\rho e^{-(T-\bar{x})^2/[2(\Sigma+\sigma)]}\dfrac{\sqrt{\Sigma}}{(\Sigma+\sigma)^{3/2}}(\bar{x}\Sigma+T\sigma)}{(1-\rho)e^{-T^2/(2\Sigma)}+\rho\dfrac{\sqrt{\Sigma}}{\sqrt{\Sigma+\sigma}}e^{-(T-\bar{x})^2/[2(\Sigma+\sigma)]}}.\tag{16.25}$$

最常用的输出信道是加性白高斯噪声（原引用 “(??)”），其输出函数为

$$g_{\text{out}}^{\text{AWGN}}(\omega,y,V)=\frac{y-\omega}{\Delta+V}.\tag{16.26}$$

统计物理研究广泛的另一线性估计例子是感知机问题，详见 Watkin 等（1993）。每个 N 维模式 F_μ 与突触权重 x_i 相乘产生输出

$$y_\mu=1,\qquad \sum_{i=1}^{N}F_{\mu i}x_i>\kappa,\tag{16.27}$$

$$y_\mu=-1,\qquad \text{其他情形},\tag{16.28}$$

κ 是与模式无关的阈值。感知机从训练模式及相应标签 y_μ 学习权重，使上述关系成立。在教师—学生情形，教师用真实权重 x_i^* 生成标签，学生只知模式和标签。可靠学习权重需要多少模式？哪些算法高效？

最简单的 $\kappa=0$ 时，重定义 $F_{\mu i}\leftarrow F_{\mu i}y_\mu$，新标签便全为 1。对应输出函数为

$$g_{\rm out}^{\rm perceptron}(\omega,V)=\frac{1}{\sqrt{2\pi V}}\frac{e^{-\omega^2/(2V)}}{H(-\omega/\sqrt{V})}, \tag{16.29}$$

$$H(x)=\int_x^\infty\frac{dt}{\sqrt{2\pi}}e^{-t^2/2}. \tag{16.30}$$

物理中详细研究过二元突触权重 $x_i\in\{\pm1\}$。将先验取为 $P_X(x)=[\delta(x-1)+\delta(x+1)]/2$，输入函数为

$$f_a^{\rm binary}(\Sigma,T)=\tanh(T/\Sigma). \tag{16.31}$$

16.3 状态演化

使用简化表述写出空腔方程。

16.3.1 带帽变量

先看 R_i 的行为，注意 ω 与 w 字母不同：

$$\frac{R_i}{\Sigma_i}=\sum_\mu B_{\mu\to i}=\sum_\mu F_{\mu i}g_{\rm out}(\omega_{\mu\to i},y_\mu,V_{\mu\to i}), \tag{16.32}$$

$$=\sum_\mu F_{\mu i}g_{\rm out}\left(\omega_{\mu\to i},f_{\rm out}\left(\sum_{j\neq i}F_{\mu j}s_j+F_{\mu i}s_i,\xi_\mu\right),V\right), \tag{16.33}$$

$$=\sum_\mu F_{\mu i}g_{\rm out}\left(\omega_{\mu\to i},f_{\rm out}\left(\sum_{j\neq i}F_{\mu j}s_j,\xi_\mu\right),V\right)+s_i\alpha\widehat{m}, \tag{16.34}$$

其中定义

$$\widehat{m}=\mathbb{E}_{\omega,z,\xi}[\partial_z g_{\rm out}(\omega,f_{\rm out}(z,\xi),V)]. \tag{16.35}$$

进一步写为

$$\frac{R_i}{\Sigma_i}\sim\mathcal{N}(0,1)\sqrt{\alpha\widehat{q}}+s_i\alpha\widehat{m}, \tag{16.36}$$

$$\widehat{q}=\mathbb{E}_{\omega,z,\xi}[g_{\rm out}^2(\omega,f_{\rm out}(z,\xi)V)]. \tag{16.37}$$

$\mathcal{N}(0,1)$ 表示零均值、单位方差的高斯随机变量。Σ 应不随格点涨落，故预期接近

$$\Sigma^{-1}(t)=\alpha\widehat{\chi}, \tag{16.38}$$

$$\widehat{\chi}=-\mathbb{E}_{\omega,z,\xi}[\partial_\omega g_{\rm out}(\omega,f_{\rm out}(z,\xi),V)]. \tag{16.39}$$

16.3.2 序参量

给定三个带帽变量，可将序参量表示为简单积分。定义

$$q=\mathbb{E}_s[\mathbb{E}_{R,\Sigma}f_a^2(\Sigma,R)], \tag{16.40}$$

$$m = \mathbb{E}_s[\mathbb{E}_{R,\Sigma} s f_a(\Sigma, R)], \tag{16.41}$$

$$V = \mathbb{E}_s[\mathbb{E}_{R,\Sigma} f_c(\Sigma, R)]. \tag{16.42}$$

记 ξ 为标准高斯变量，原文立即得到

$$q^t = \mathbb{E}_s\left[\mathbb{E}_\xi f_a^2\left((\alpha\widehat{\chi}^t)^{-1}, (\alpha\widehat{\chi}^t)^{-1}(\sqrt{\widehat{q}^t} + \alpha\widehat{m})s\xi\right)\right], \tag{16.43}$$

$$m^t = \mathbb{E}_s\left[\mathbb{E}_\xi s f_a\big((\alpha\widehat{\chi}^t)^{-1}, \alpha\widehat{\chi}^t\big)^{-1}(\sqrt{\widehat{q}^t} + \alpha\widehat{m})\right], \tag{16.44}$$

$$V^t = \mathbb{E}_s\left[\mathbb{E}_\xi f_c\big((\alpha\widehat{\chi}^t)^{-1}, \alpha\widehat{\chi}^t\big)^{-1}(\sqrt{\widehat{q}^t} + \alpha\widehat{m})\right]. \tag{16.45}$$

16.3.3 回到带帽变量

将带帽变量写为序参量的函数即可闭合。由定义，z, ω 联合高斯：

$$\begin{bmatrix} z \\ \omega \end{bmatrix} \sim \mathcal{N}\left(0, \begin{pmatrix} q_0 & m^t \\ m^t & q^t \end{pmatrix}\right). \tag{16.46}$$

将定义汇总，得到三维积分：

$$\widehat{m}^{t+1} = \mathbb{E}^t_{\omega,z,\xi}[\partial_z g_{\text{out}}(\omega, f_{\text{out}}(z,\xi), V^t)], \tag{16.47}$$

$$\widehat{q}^{t+1} = \mathbb{E}^t_{\omega,z,\xi}[g^2_{\text{out}}(\omega, f_{\text{out}}(z,\xi), V^t)], \tag{16.48}$$

$$\widehat{\chi}^{t+1} = -\mathbb{E}^t_{\omega,z,\xi}[\partial_\omega g_{\text{out}}(\omega, f_{\text{out}}(z,\xi)), V^t]. \tag{16.49}$$

译注： 源式 (16.37) 在 f_{out} 与 V 之间缺逗号，(16.42) 使用此前未定义的 f_c；(16.43) 的 $s\xi$ 乘法与根号缩放、(16.44)–(16.45) 的括号和 -1 位置均按可见原式保留，不代为改成常用状态演化。式 (16.49) 将 V^t 放在函数括号外也保持。此组源记号不足以直接作为经核实的数值算法。

16.4 从 r-BP 到 G-AMP

r-BP 虽可实现，但消息对目标节点的依赖很弱，因此还能在保持边缘主导阶行为的同时进一步简化。这与原文所引第 9 节从普通 BP 得到 TAP 方程的做法相同。

Taylor 展开后的修正汇成 Onsager 反作用项，参见 Thouless 等（1977）。最终 G-AMP 只用每个 x_i 的均值 a_i 和方差 c_i 表示，推导保留 a_i 的主导阶。因此原文认为，既然 BP 渐近精确，G-AMP 的均值和方差也渐近精确。定义

$$\omega_\mu^{t+1} = \sum_i F_{\mu i} a^t_{i\to\mu}, \tag{16.50}$$

$$V_\mu^{t+1} = \sum_i F_{\mu i}^2 v^t_{i\to\mu}, \tag{16.51}$$

$$\Sigma_i^{t+1} = \frac{1}{\sum_\mu A^{t+1}_{\mu\to i}}, \tag{16.52}$$

$$R_i^{t+1} = \frac{\sum_\mu B^{t+1}_{\mu\to i}}{\sum_\mu A^t_{\mu\to i}}. \tag{16.53}$$

V 的修正很小，故

$$V_\mu^{t+1} = \sum_i F_{\mu i}^2 v^t_{i\to\mu} \approx \sum_i F_{\mu i}^2 v_i^t. \tag{16.54}$$

此后用 $\approx$ 表示仅在主导阶成立的等式。由 A, B 的定义，

$$\begin{aligned}\Sigma_i &= \left[-\sum_\mu F_{\mu i}^2 \partial_\omega g_{\text{out}}(\omega_{\mu\to i}^{t+1}, y_\mu, V_{\mu\to i}^{t+1})\right]^{-1} \\ &\approx \left[-\sum_\mu F_{\mu i}^2 \partial_\omega g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1})\right]^{-1}, \\ R_i &= \left[-\sum_\mu F_{\mu i}^2 \partial_\omega g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1})\right]^{-1} \\ &\quad \times \left[\sum_\mu F_{\mu i} g_{\text{out}}(\omega_{\mu\to i}^{t+1}, y_\mu, V_{\mu\to i}^{t+1})\right].\end{aligned}$$

再写为

$$\begin{aligned} g_{\text{out}}(\omega_{\mu\to i}^{t+1}, y_\mu, V_{\mu\to i}^{t+1}) &\approx g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1}) \\ &\quad - F_{\mu i} a_{i\to\mu}^t \partial_\omega g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1}), \qquad (16.55) \\ &\approx g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1}) \\ &\quad - F_{\mu i} a_i^t \partial_\omega g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1}). \qquad (16.56)\end{aligned}$$

最终得到

$$\begin{aligned}(\Sigma_i)^{t+1} &= \left[-\sum_\mu F_{\mu i}^2 \partial_\omega g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1})\right]^{-1}, \qquad (16.57) \\ R_i^{t+1} &= ((\Sigma_i)^{t+1})^{-1} \\ &\quad \times \left[\sum_\mu F_{\mu i} g_{\text{out}}(\omega_\mu, y_\mu, V_\mu) - F_{\mu i}^2 a_i \partial_\omega g_{\text{out}}(\omega_\mu, y_\mu, V_\mu)\right], \qquad (16.58) \\ &= a_i^t + ((\Sigma_i)^{t+1})^{-1} \sum_\mu F_{\mu i} g_{\text{out}}(\omega_\mu^{t+1}, y_\mu, V_\mu^{t+1}). \qquad (16.59)\end{aligned}$$

接着考虑 $a_{i\to\mu}$：

$$\begin{aligned} a_{i\to\mu}^t &= f_a(R_{i\to\mu}^t, \Sigma_{i\to\mu}^t) \approx f_a(R_{i\to\mu}^t, \Sigma_i), \qquad (16.60) \\ &\approx f_a(R_i^t, \Sigma_i) - B_{\mu\to i}^t f_v(R_i^t, \Sigma_i), \qquad (16.61) \\ &\approx a_i^t - g_{\text{out}}(\omega_\mu^t, y_\mu, V_\mu^t) F_{\mu i} v_i^t. \qquad (16.62)\end{aligned}$$

因此

$$\begin{aligned}\omega_\mu^{t+1} &= \sum_i F_{\mu i} a_i^t - \sum_i g_{\text{out}}(\omega_\mu^t, y_\mu, V_\mu^t) F_{\mu i}^2 v_i^t \\ &= \sum_i F_{\mu i} a_i - V_\mu^t g_{\text{out}}(\omega_\mu^t, y_\mu, V_\mu^t). \qquad (16.63)\end{aligned}$$

算法中式 (16.65) 的 Onsager 项使用 $t-1$ 指标，对收敛至关重要，原因与原文所引第 9 节 TAP 方程相同。整个算法只用矩阵乘法，便于利用快速线性代数实现。**译注：** 原文对 TAP 的第 9 节指向与现版章节位置需区分；前面实际第 11 章有相应稠密推导。式 (16.53) 分母时标、(16.58)–(16.59) 的 Σ^{-1}、(16.60) 的 f_a 自变量顺序、c/v 及最后 a_i 时标均保留，不按实现需要静默修复。边缘精确性的继承仍依赖原 BP 适用条件和所用渐近展开。

算法 2：广义近似消息传递（G-AMP）

输入 y。初始化 $a^0, v^0, g_{\mathrm{out},\mu}^0$，令 $t=1$。重复更新：

1. 更新 ω_μ, V_μ：

$$V_\mu^t \leftarrow \sum_i F_{\mu i}^2 v_i^{t-1}, \tag{16.64}$$

$$\omega_\mu^t \leftarrow \sum_i F_{\mu i} a_i^{t-1} - V_\mu^t g_{\mathrm{out}}^{t-1}. \tag{16.65}$$

2. 更新 $\Sigma_i, R_i, g_{\mathrm{out},\mu}$：

$$\Sigma_i^t \leftarrow \left[-\sum_\mu F_{\mu i}^2 \partial_\omega g_{\mathrm{out}}(\omega_\mu^t, y_\mu, V_\mu^t) \right]^{-1}, \tag{16.66}$$

$$R_i^t \leftarrow a_i^{t-1} + (\Sigma_i^t)^{-1} \sum_\mu F_{\mu i} g_{\mathrm{out}}(\omega_\mu^t, y_\mu, V_\mu^t). \tag{16.67}$$

3. 更新估计边缘 a_i, v_i：

$$a_i^{t+1} \leftarrow f_a(\Sigma_i, R_i^{t+1}, \,), \tag{16.68}$$

$$v_i^{t+1} \leftarrow f_v(\Sigma_i, R_i^{t+1}). \tag{16.69}$$

令 $t \leftarrow t+1$，直至 a, v 收敛，输出 a, v。**译注：** 原算法位于物理页 261；Σ^{-1}、更新 R_i^t 后读取 R_i^{t+1} 以及 f_a 的尾随空参数按源保留。它们是已定位源问题，并非译者提供的可直接执行修订算法。

16.5　贝叶斯与凸优化的严格结果

16.5.1　贝叶斯最优

贝叶斯最优时，Nishimori 条件给出 $q=m$、$V=q_0-m$、$\widehat{q}=\widehat{m}=\widehat{\chi}$，从而大幅简化方程。

原文指出，可严格证明如下结论：统计物理文献所谓“平均自由能”，即变量数增长时 Y 的渐近熵密度，为

$$\lim_{n\to\infty} \frac{H(Y \mid \Phi)}{n} = -\sup_{r\ge 0} \inf_{q\in[0,\rho]} \left\{ \psi_{P_0}(r) + \alpha \Psi_{P_{\mathrm{out}}}(q;\rho) - \frac{rq}{2} \right\}, \tag{16.70}$$

其中 $q_0=\rho=\mathbb{E}[x^2]$，用 D 表示高斯积分，定义

$$\psi_{P_0}(r) := \int Dz\, dP_0(X_0) \ln \int dP_0(x) e^{rxX_0 + \sqrt{r}xz - rx^2/2}, \tag{16.71}$$

$$\begin{aligned} \Psi_{P_{\mathrm{out}}}(q;\rho) := & \int DV\, DW\, d\widetilde{Y}_0\, P_{\mathrm{out}}(\widetilde{Y}_0 \mid \sqrt{q}V + \sqrt{\rho-q}W) \\ & \times \ln \int Dw\, P_{\mathrm{out}}(\widetilde{Y}_0 \mid \sqrt{q}V + \sqrt{\rho-q}w). \end{aligned} \tag{16.72}$$

容易检验，在 Nishimori 点上状态演化为

$$m^{t+1} = \psi_{P_0}'(\widehat{m}^t)/2, \tag{16.73}$$

$$\widehat{m}^t = \alpha \Psi_{P_{\mathrm{out}}}'(m^t;\rho)/2. \tag{16.74}$$

译注： 源文在此给出严格结果的表述，未逐项写全先验、信道、矩阵和熵存在性的定理假设；Φ/F 记号及状态演化的 $1/2$ 因子原样保留。本轮翻译未独立证明或补全其数学假设。

16.5.2 贝叶斯最优

另一类有严格结果的问题，是相应优化为凸问题的情形。**译注：**本小节标题在原文重复为“Bayes-Optimal”，正文仅此一句；保留未展开状态，不补写凸优化定理。

16.6 应用：LASSO、稀疏估计与压缩感知

16.6.1 有限 Δ 的 AMP

此时 $f_{\text{out}}^{\text{AWGN}} = x + \xi$，输出函数为

$$g_{\text{out}}^{\text{AWGN}}(\omega, y, V) = \frac{y - \omega}{\Delta + V}. \tag{16.75}$$

算法 3：用于线性估计的近似消息传递（AMP）

输入 y，初始化 $a^0, v^0, g_{\text{out},\mu}^0$，令 $t = 1$。重复更新：

1. 更新 ω_μ, V_μ：

$$V_t \leftarrow \frac{1}{N}\sum_i v_i^{t-1}, \tag{16.76}$$

$$\omega_\mu^t \leftarrow \sum_i F_{\mu i} a_i^{t-1} - V_\mu^t g_{\text{out}}^{t-1}. \tag{16.77}$$

2. 更新 $\Sigma_i, R_i, g_{\text{out},\mu}$：

$$\Sigma_t \leftarrow \frac{\Delta + V_t}{\alpha}, \tag{16.78}$$

$$R_i^t \leftarrow a_i^{t-1} + \sum_\mu F_{\mu i}\frac{y_\mu - \omega_\mu}{\alpha}. \tag{16.79}$$

3. 更新估计边缘：

$$a_i^{t+1} \leftarrow f_a(\Sigma_t, R_i^{t+1},), \tag{16.80}$$

$$v_i^{t+1} \leftarrow f_v(\Sigma^t, R_i^{t+1}). \tag{16.81}$$

令 $t \leftarrow t+1$，直至 a, v 收敛，输出 a, v。原算法位于源物理页 262，V_t/V_μ^t、时标和尾随空参数保持原式。

16.6.2 LASSO：无穷大 Δ

作变量替换 $V = \Delta\widetilde{V}$、$\Sigma = \Delta\widetilde{\Sigma}$。$\Delta$ 大时，f_a, f_b 可用 Laplace 积分计算，最终方程闭合为原算法，将 Δ 换成 1，更新函数取为

$$\begin{aligned} f_a^{\text{MAP}}(\Sigma, R) &= \frac{\int dx\, x P_X(x) e^{-(x-R)^2/(2\Delta\widetilde{\Sigma})}}{\int dx\, P_X(x) e^{-(x-R)^2/(2\Delta\widetilde{\Sigma})}} \\ &= \underset{x}{\text{argmin}}\left[-\frac{(x-R)^2}{2\widetilde{\Sigma}} + \lambda f_{\text{reg}}(x)\right], \end{aligned} \tag{16.82}$$

$$f_v(\Delta\widetilde{\Sigma}, R) = \Delta\widetilde{\Sigma}\partial_R f_a(\widetilde{\Sigma}, R). \tag{16.83}$$

例如，ℓ_1 正则化给出 $f_a^{\mathrm{MAP}}(\Sigma,R)=\mathrm{argmin}_x[(x-R)^2/(2\widetilde{\Sigma})+\lambda|x|]$，从而

$$f_a^{\mathrm{ST}}(\Sigma,R)=0, \qquad |R|<\lambda\Sigma, \tag{16.84}$$

$$=R-\lambda\Sigma, \qquad R>\lambda\Sigma, \tag{16.85}$$

$$=R+\lambda\Sigma, \qquad R<\lambda\Sigma, \tag{16.86}$$

$$\tag{16.87}$$

以及

$$f_c^{\mathrm{ST}}(\Sigma,R)=0, \qquad |R|<\lambda\Sigma, \tag{16.88}$$

$$=\Sigma, \qquad \text{其他情形.} \tag{16.89}$$

译注： 原文 $f_b/f_v/f_c$ 及 Σ 的上下标混用保留。式 (16.82) 的二次项确为负，与下一句的正二次项不同；无穷噪声到 MAP 的极限需先验 / 温度的配套缩放，不能仅从所写积分得出。式 (16.86) 原条件确为 $R<\lambda\Sigma$，缺少负号，(16.87) 是原空编号；这里没有将其静默改成常用软阈值实现。

算法 4：用于 LASSO 的近似消息传递（AMP）

输入 y，初始化 $a^0,v^0,g^0_{\mathrm{out},\mu}$，令 $t=1$。重复更新：

1. 更新 ω_μ,V_μ：

$$V_t\leftarrow\frac{1}{N}\sum_i v_i^{t-1}, \tag{16.90}$$

$$\omega_\mu^t\leftarrow\sum_i F_{\mu i}a_i^{t-1}-V_\mu^t g_{\mathrm{out}}^{t-1}. \tag{16.91}$$

2. 更新 $\Sigma_i,R_i,g_{\mathrm{out},\mu}$：

$$\Sigma_t\leftarrow\frac{1+V_t}{\alpha}, \tag{16.92}$$

$$R_i^t\leftarrow a_i^{t-1}+\sum_\mu F_{\mu i}\frac{y_\mu-\omega_\mu}{\alpha}. \tag{16.93}$$

3. 更新估计边缘：

$$a_i^{t+1}\leftarrow f_a^{\mathrm{ST}}(\Sigma_t,R_i^{t+1},), \tag{16.94}$$

$$v_i^{t+1}\leftarrow f_v^{\mathrm{ST}}(\Sigma_t,R_i^{t+1}). \tag{16.95}$$

令 $t\leftarrow t+1$，直至 a,v 收敛，输出 a,v。原算法位于物理页 263，移到对应小节，记法保留；f_v^{ST} 与正文 f_c^{ST} 的差异未修。

- 容易相：AMP 能找到最优解。
- 困难相：最优解可由穷举等方式找到，但 AMP 陷于局部极小值，给出错误答案。
- 不可能相：任何算法都无法找到解。

猜想： 困难相中，没有算法能在多项式时间内奏效。**译注：** 上述相图及“解”针对本节匹配先验、无噪声、大维度的典型恢复情形；不将其扩展为任意有限实例、估计误差准则或一般矩阵的绝对不可解结论。多项式困难明确为原作者猜想。

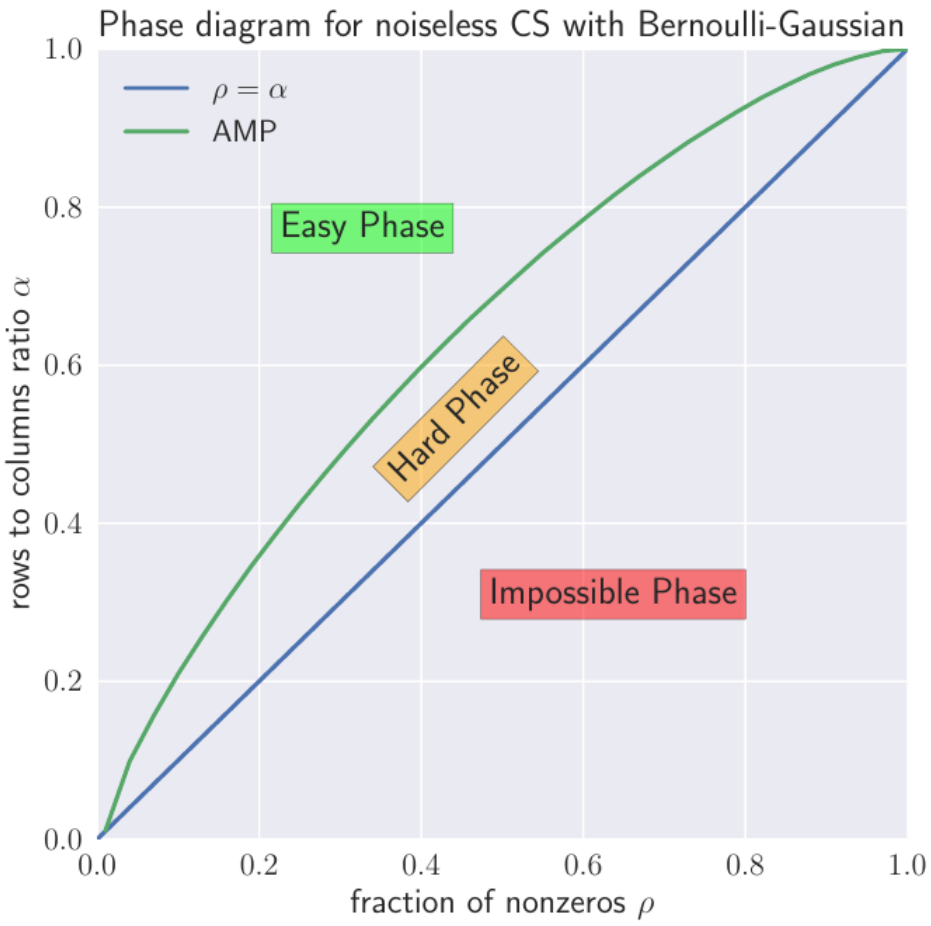


图 16.6.1: 高斯—Bernoulli 先验的无噪声压缩感知相图。横轴为非零分量比例 ρ，纵轴为行列比 α；蓝线为 $\rho = \alpha$，绿线为 AMP 阈值。Easy / Hard / Impossible 分别为容易 / 困难 / 不可能相。原图裁自源物理页 258。

文献

Donoho 等（2009）、Krzakala 等（2012），以及 Zdeborová 与 Krzakala（2016）。

16.7 习题

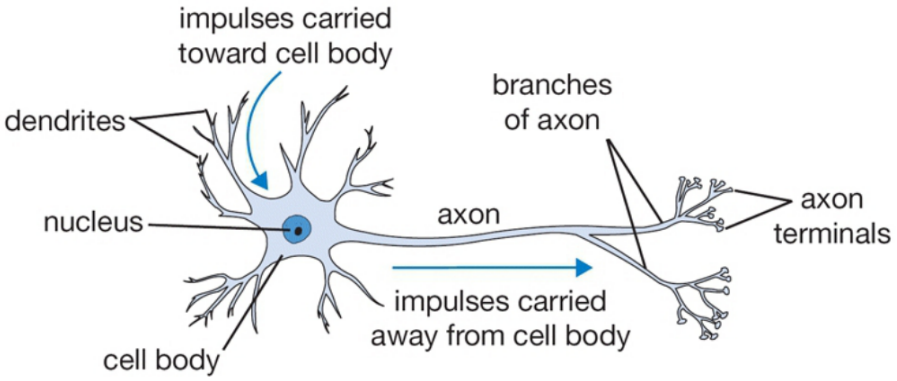
习题 16.1：用于稀疏估计的 AMP。考虑 N 维稀疏 Bernoulli 信号 x_0，每个元素抽自

$$x_0 \sim (1-\rho)\delta(x) + \rho\mathcal{N}(0,1). \tag{16.96}$$

测量为 $y = Fx_0$，其中 F 是本章所用的 $M \times N$ 随机矩阵。对不同的 ρ, α 及适中 N（数百），运行贝叶斯最优和 LASSO 两种 AMP，估计 x_0，展示两者均可有效。附加题：与各自状态演化比较。**译注：**原文称信号为 Bernoulli，所列分布实际为高斯—Bernoulli 混合；保留原式和实验要求。本轮为翻译，未运行这些习题或提供修订后的可执行算法。

17 感知机

17.1 感知机



图内文字：dendrites：树突；nucleus：细胞核；cell body：胞体；axon：轴突；branches of axon：轴突分支；axon terminals：轴突末端。弯曲蓝箭头表示神经冲动传向胞体，沿轴突的直蓝箭头表示神经冲动离开胞体。

1943 年，McCulloch–Pitts 模型：$y = \text{Heavyside}(\xi \cdot w - \kappa)$，其中 ξ 是经树突传来的信号，w 是突触权重。

1958 年，Rosenblatt 用机械方式构造 McCulloch–Pitts 模型。给定模式 $\{\xi_1, \ldots, \xi_n\}$ 和目标 $y_i \in \{0, 1\}$，要对新模式 ξ_{new} 判定其目标。

1969 年，Minsky 与 Papert 介绍感知机：McCulloch–Pitts 模型学习一个分离超平面，因此不能学习线性不可分的情形，例如 XOR 问题。

把点嵌入更高维空间，便有可能找到分离超平面，这称为表示学习。

- 思路 1：线性嵌入。点仍处在低维空间里，不行。
- 思路 2：非线性嵌入，例如核方法、深度神经网络。

译注：这是原讲义的历史与概念提纲；“Heavyside” 及 1969 年的叙述沿用原文，未另作史料修订。非线性嵌入的可分性还依赖特征映射和数据，不能解释为任意嵌入均保证可分。

用统计物理研究感知机

将 Heavyside 换成符号函数。$\{0,1\}$ 到 $\{-1,1\}$ 的双射不改变分析，而物理更常使用 ±1 自旋。

容量

1988 年，Derrida、Gartner。

考虑 M 个长为 N 的二元模式 ξ_μ（$\mu=1,\dots,M$），标签 $y_\mu\in\{-1,1\}$ 独立同分布生成。目标是学习 $w\in\{-1,1\}^N$，作预测 $\widehat{y}(x)=\operatorname{sign}(\xi\cdot w)$，并最小化成本

$$\mathcal{H}\big(w;\{\xi_\mu,y_\mu\}_{\mu=1}^M\big)=M-\sum_\mu\delta(y_\mu,\widehat{y}(\xi_\mu)).$$

令 $\alpha=M/N$。观察到存在阈值 α_c，使 $N\to\infty$、α 固定时：

- $\alpha<\alpha_c$，以高概率存在 w 使 $\mathcal{H}=0$。
- $\alpha>\alpha_c$，以高概率对所有 w 均有 $\mathcal{H}>0$。

存储容量定义为 $M_{\text{capacity}}=\alpha_cN$。

副本法

1989 年，Knuth、Mezard，《Storage capacity of memory networks with binary couplings》（原文署名）。

逆温度 β 的 Boltzmann 配分函数为

$$Z\big(\beta;\{\xi_\mu,y_\mu\}_{\mu=1}^M\big)=\sum_w\exp\big[-\beta\mathcal{H}(w;\{\xi_\mu,y_\mu\}_{\mu=1}^M)\big].$$

$\beta\to\infty$ 时，配分函数趋于“好”权重的数目，原文写为

$$\lim_{\beta\to\infty}Z\big(\beta;\{\xi_\mu,y_\mu\}_{\mu=1}^M\big)=\big|\{w\mid\mathcal{H}(w;\{\xi_\mu,y_\mu\}_{\mu=1}^M)=0\}\big|.$$

关注所有可能训练集上的平均自由熵

$$\Phi(\beta,\alpha)=\lim_{N\to\infty}\mathbb{E}_{\{\xi_\mu,y_\mu\}_{\mu=1}^M}\left[\frac{\log Z(\beta;\{\xi_\mu,y_\mu\}_{\mu=1}^M)}{N}\right].$$

副本法给出

$$\begin{aligned}\Phi_{\text{RS}}(\beta,\alpha)=\operatorname{Ext}_{q,\widehat{q}}\Bigg\{&\frac{1}{2}q\widehat{q}-\frac{1}{2}\widehat{q}+\int Dz\log[2\cosh(z\sqrt{\widehat{q}})]\\&+\alpha\int Dz\log\left[e^{-\beta}+(1-e^{-\beta})H\left(z\sqrt{\frac{q}{1-q}}\right)\right]\Bigg\},\\H(x)=\int_x^\infty du\,\frac{e^{-u^2/2}}{\sqrt{2\pi}}&=\frac{1}{2}\operatorname{erfc}\left(\frac{x}{\sqrt{2}}\right).\end{aligned}$$

原文指出，严格证明 $\alpha_c \approx 0.83$ 以下 Φ_{RS} 正确仍是开放问题，正确性只是基于副本公式的信念。$\alpha > \alpha_c$ 时，RS 不正确，需要 1RSB 分析。**译注：** 这里 “仍是开放问题” 指原讲义当时的表述，不是本轮检索确认的当前状态。“Knuth” 与常见文献署名存在疑点，未静默改作者；配分函数极限右端按源保留集合外的一对基数竖线，表示满足零代价条件的权重数。随机标签存储容量与后面的教师生成标签不同。

教师—学生情形

- 教师：$y^* = \mathrm{sign}(\xi \cdot w^*)$，$w^*$ 也是二元权重。模式仍随机，标签按教师规则生成。
- 学生：学习此规则。由于存在真实 w^*，这里没有前述容量限制；问题变为学生需见多少模式才能学会规则。

将 ξ_μ 视为矩阵 F 的第 μ 行，将 w^* 视为待恢复信号 x^*，则

$$y = \mathrm{sign}(Fx).$$

用概率框架表述：在符号函数内加入高斯噪声，得到 probit 似然，并取二元权重 $x \in \{+1, -1\}^N$。完整模型原写为

$$\begin{cases} x_i \sim \frac{1}{2}\delta(x_i - 1) + \frac{1}{2}\delta(x_i + 1), \\ y_\mu \sim \frac{1}{2}\,\mathrm{erfc}\left(\frac{1}{\sqrt{2\sigma^2}} F_\mu \cdot x\right). \end{cases}$$

它与广义线性模型相同，可以用 AMP 处理。记先验为 $P_X(x)$，$\rho = \mathbb{E}[x^2]$，副本公式为

$$\lim_{N\to\infty} \mathbb{E}_{F,y}\left[\frac{\log Z(F,y)}{N}\right] = \mathrm{Ext}_{q,\widehat{q}}\, \Phi_{\mathrm{RS}}(q, \widehat{q}),$$

其中

$$\begin{aligned} \Phi_{\mathrm{RS}}(q,\widehat{q}) = -\frac{\alpha}{2} q\widehat{q} + \alpha \int dx^* dy\, Dz\, P_{\mathrm{out}}(y \mid x^*\sqrt{\rho - q} + z\sqrt{q}) \\ \times \log\left\{ \int dx\, P_{\mathrm{out}}(y \mid x\sqrt{\rho - q} + z\sqrt{q}) \right\} \\ + \int dx^* Dz\, P_X(x^*) e^{-\alpha\widehat{q}(x^*)^2/2 + zx^*\sqrt{\widehat{q}}} \\ \times \log\left\{ \int dx\, P_X(x) e^{-\alpha\widehat{q}x^*/2 + zx\sqrt{\widehat{q}}} \right\}. \end{aligned}$$

极值点 q^* 等于 $\langle x^*, \widehat{x}\rangle_{F,\psi}$。**译注：** 原 probit 模型把 $y_\mu \sim$ 接在一个数值概率表达式前，未明确标签条件概率；噪声、符号和归一化约定需另行说明。一般 RS 势的输出项使用 dx^*, dx 而非明确高斯测度，输入项最后指数写 x^*、平方和 α 因子位置也不统一；F, ψ 的下标记号保持，不补成标准公式。

AMP 状态演化

$$\widehat{q}^{(t)} = -\int dp\, dx\, \frac{\exp[-p^2/(2q^{(t)}) - (x-p)^2/(2(\rho - q^{(t)}))]}{2\pi\sqrt{q^{(t)}(\rho - q^{(t)})}}$$

$$\times \int dy\, P_{\text{out}}(y \mid x) \partial_p g_{\text{out}}(p, y, \rho - q^{(t)}),$$

$$q^{(t+1)} = \int dx\, P_X(x) \int Dz\, f_a^2 \left(\frac{1}{\alpha \widehat{q}^{(t)}}, x + \frac{z}{\sqrt{\alpha \widehat{q}^{(t)}}} \right).$$

- 不可能相：$\alpha < 1.245$ 时，$q = 1$ 不是 Φ_{RS} 的全局极大值，因此无法找到解。
- 困难相：$\alpha \in (1.245, 1.493)$ 时，$q = 1$ 是全局极大值，但还有另一个局域极大值，AMP 会困在那里。
- 容易相：$\alpha > 1.493$ 时，$q = 1$ 是唯一局域极大值，AMP 总会收敛到它。

译注：以上“不可能”指该模型语境下的完整教师权重恢复，不能理解为教师标签约束无解；教师本身已提供一个一致权重。给定噪声、先验和矩阵归一化对阈值有影响，原文未在此列明所有数值阈值条件。势的极值结构也不能单独证明所有有限实例、所有初始化的 AMP 收敛，以上保持原作者的渐近模型讨论。

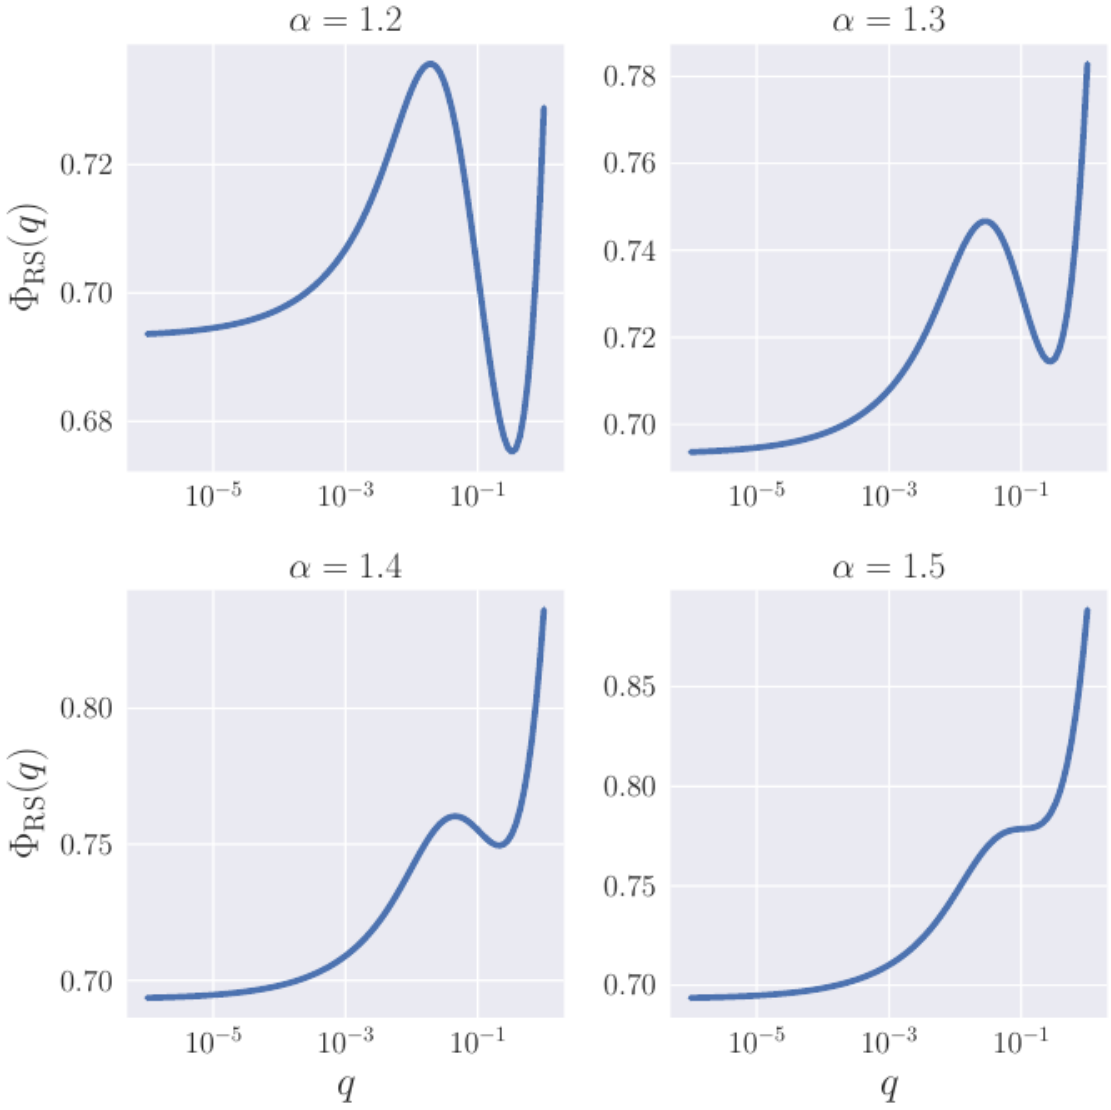


图 17.1.1: 不同 α 下感知机的自由熵 $\Phi_{\mathrm{RS}}(q)$。四图依次为 $\alpha = 1.2, 1.3, 1.4, 1.5$，横轴 q 采用对数刻度。忠实裁自源物理页 269。

18 高维回归：精确渐近结果

> 数学科学的若干分支都使用“维数灾难”一词；这里我用它指系统搜索高维空间、准确逼近一般高维函数以及对高维函数积分，看起来都难以处理。维数带来的益处却较少受到关注，其中包括测度集中现象（Banach 空间几何中的用语），即某些随机涨落在高维中得到很好的控制；还有数学统计和统计物理中广泛使用的渐近方法的成功：中等维数可能复杂难解的问题，在极高维情形反而能够作出明确陈述。
>
> David Donoho，2000

18.1 线性模型的 AMP

考虑 AMP 递推

$$x^{t+1} = f_t(x^t + A^T r^t/\alpha), \tag{18.1}$$

$$r_t = y - Ax + \frac{1}{\alpha} b_t r^{t-1}. \tag{18.2}$$

它显然是 GAMP 的实例。取 $g_t(v^t) = y - v^t = r^t$、$e(u) = \mathrm{Prox}(u/\alpha)$，则

$$u^{t+1} = A^T(y - v^t) + \alpha\,\mathrm{Prox}(u^t/\alpha), \tag{18.3}$$

$$v^t = A\,\mathrm{prox}(u^t/\alpha) - V_t g_{t-1}(v^{t-1}). \tag{18.4}$$

使用 $x = \mathrm{prox}(u/\alpha)$ 和 $r = y - v$，有

$$u^{t+1} = A^T r_t + \alpha x, \tag{18.5}$$

$$r^t = y - v^t = y - A\,\mathrm{prox}(u^t) + b_t g_{t-1}(v^{t-1}) = y - Ax + V_t r, \tag{18.6}$$

其中 $V_t = \alpha^{-1}\mathbb{E}[\mathrm{prox}'(u/\alpha)]$。

所以可对这个 AMP 实例写出状态演化。关键是，若 AMP 收敛，在某时刻 t^* 有

$$r_{t^*} = \frac{y - Ax}{1 - b_{t^*}/\alpha}, \tag{18.7}$$

$$x = \mathrm{Prox}_{t^*}\left(x + \frac{A^T(y - Ax)}{\alpha - b_{t^*}}\right). \tag{18.8}$$

这就是参数 $\eta = 1/(\alpha - b)$ 的近端优化算法不动点。原文据此说：采用相应 AMP 递推，便可求解 LASSO，乃至任何凸优化问题！

在最简单的 $y = Ax_0 + \sqrt{\Delta}\xi$ 情形，u, v 均为高斯变量，需要跟踪其方差以及在 x_0, y 方向的投影：

$$\begin{aligned} q_u^{t+1} &= \alpha\mathbb{E}[(g_t^{\mathrm{out}}(\omega, \phi(z_0)))^2] = \alpha\mathbb{E}[(y - w)^2] = \alpha(\rho + q_\omega - 2m_\omega + \Delta) \\ &= \alpha(E^t + \Delta), \end{aligned} \tag{18.9}$$

$$q_\omega^t = \mathbb{E}[e_t^{\mathrm{in}}(\sqrt{q_u^t}Z + m_u^t x_0)^2], \tag{18.10}$$

$$m_u^{t+1} = \alpha\mathbb{E}[\partial_{z_0}(g_t^{\mathrm{out}}(\sqrt{q_\omega^t}Z' + m_\omega^t z_0, \phi(z_0)))] = \alpha, \tag{18.11}$$

$$m_\omega^t = \mathbb{E}[e_t^{\mathrm{in}}(\sqrt{q_u^t}Z + m_u^t x_0)x_0]. \tag{18.12}$$

只保留 q, m 并采用前面的近端算子，可写为

$$q^{t+1} = \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(\rho + q^t - 2m^t + \Delta)}Z + x_0)^2], \tag{18.13}$$

$$m^{t+1} = \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(\rho + q^t - 2m^t + \Delta)}Z + x_0)x_0]. \tag{18.14}$$

更直接地，

$$\begin{aligned} E^{t+1} = \rho &+ \mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(E^t + \Delta)}Z + x_0)^2] \\ &- 2\mathbb{E}[f_t^{\text{in}}(\sqrt{\alpha^{-1}(E^t + \Delta)}tZ + x_0)x_0]. \end{aligned}$$

译注： 原文残差的 r_t/r^t、V_t/b_t、(18.6) 中缺少的 $/\alpha$、w/ω 及最后一式额外的 tZ 均保持。相同不动点并不自动证明 AMP 收敛或可求解任意凸优化；还需正步长、惩罚的匹配、矩阵系综及相应收敛条件。

18.1.1 岭回归的例子

采用岭回归，近端算子为 $f_{\lambda\eta}(u) = u/(\lambda\eta+1)$。收敛后，由 $\eta = 1/(\alpha - b_{\text{eq}})$、$b_{\text{eq}} = 1/(\lambda\eta+1)$，必有[12]

$$b_{\text{eq}} = \frac{1}{1 + \lambda/(\alpha - b_{\text{eq}})}.$$

接下来的方程是

$$q = \frac{1 + \alpha^{-1}(1 + q - 2m + \Delta)}{(\lambda/(\alpha - b) + 1)^2}, \tag{18.15}$$

$$m = \frac{1}{\lambda/(\alpha - b) + 1} = \frac{\alpha - b}{\lambda + \alpha - b}. \tag{18.16}$$

当 $\alpha > 1$ 时，$\lambda = 0$ 有一个有趣的解：$m = 1$，且

$$\begin{aligned} q &= 1 + \alpha^{-1}(1 + q - 2 + \Delta), \\ q(1 - \alpha^{-1}) &= 1 + (\Delta - 1)/\alpha, \\ q &= \frac{1 - \alpha^{-1} + \Delta/\alpha}{1 - \alpha^{-1}} = 1 + \frac{\Delta}{\alpha - 1}. \end{aligned}$$

恢复信号的误差为 $E = \Delta/(\alpha - 1)$，在 $\alpha = 1$ 发散！

还有另一种极限。取 $b = \alpha - \lambda c$，在 $\lambda \to 0^+$ 时求解 c，得到对应 “伪范数” 的解 $b = \alpha$。这适用于 $\alpha < 1$。此时 $m = \alpha$，并有

$$\begin{aligned} q &= \alpha^2(1 + \alpha^{-1}(1 + q - 2\alpha + \Delta)) \\ &= \alpha^2 + \alpha + \alpha q - 2\alpha^2 + \alpha\Delta, \\ q(1 - \alpha) &= \alpha(1 - \alpha + \Delta), \\ q &= \frac{\alpha(1 - \alpha + \Delta)}{1 - \alpha}. \end{aligned}$$

[12] 有些论文使用变量替换 $V/(1+V) = b/\alpha$，得到自洽方程 $V_{\text{eq}} = 1/(\lambda + \alpha/(1 + V_{\text{eq}}))$。

误差为 $E = 1 + \alpha(1-\alpha+\Delta)/(1-\alpha) - 2\alpha$，即原文写出的

$$E = \frac{1+\alpha+\alpha(1-\alpha+\Delta)-2\alpha+2\alpha^2}{1-\alpha} = \frac{1+\alpha\Delta+\alpha^2}{1-\alpha}.$$

因此，当 $\lambda \to 0^+$ 时，泛化误差 $E+\Delta$ 为

$$\epsilon_{\text{gen}} = \frac{1+\alpha^2+\Delta}{1-\alpha}, \qquad \alpha < 1, \tag{18.17}$$

$$\epsilon_{\text{gen}} = \frac{\Delta\alpha}{1-\alpha}, \qquad \alpha > 1. \tag{18.18}$$

此外，仍有

$$r_{t^*} = \frac{y - Ax}{1 - b_{t^*}/\alpha}. \tag{18.19}$$

因此，训练误差（原文称向量 $y-Ax$ 的平均值）与 r 的误差满足

$$\epsilon_{\text{train}} = \mathbb{E}[(y-Ax)^2] = \mathbb{E}[r^2]\left(1-\frac{b}{\alpha}\right)^2 = \epsilon_{\text{gen}}\left(1-\frac{b}{\alpha}\right)^2. \tag{18.20}$$

在 $\lambda \to 0^+$ 时得到

$$\epsilon_{\text{train}} = 0, \qquad \alpha < 1, \tag{18.21}$$

$$\epsilon_{\text{train}} = \frac{\Delta(\alpha-1)}{\alpha}, \qquad \alpha > 1. \tag{18.22}$$

译注： 原文在 $\alpha < 1$ 分支的通分中写出 $1+\alpha$，与前行不相符；(18.18) 的分母 $1-\alpha$ 会使 $\Delta > 0, \alpha > 1$ 时误差为负，亦与前文 $E = \Delta/(\alpha-1)$ 不符。此处忠实保留并定位，不把这些负误差公式作为已核实的统计结果；“伪范数” 为原文用词。

18.1.2 一般协变量的岭回归

考虑更一般的变体。给定 m 对高斯协变量，每对有两个向量，分布为

$$\begin{bmatrix} u \in \mathbb{R}^d \\ v \in \mathbb{R}^p \end{bmatrix} \sim \mathcal{N}\left(0, \begin{bmatrix} 1 & \Phi \\ \Phi^T & \Omega \end{bmatrix}\right). \tag{18.23}$$

数据由 $y = u \cdot \theta^*/\sqrt{d}$ 生成，但只给我们 v，要求在 p 个参数上作岭回归：

$$\begin{aligned} \widehat{X} &= \operatorname*{argmin}_X \left\{ \|Y - VX/\sqrt{p}\|_2^2 + \lambda \|X\|_2^2 \right\} \\ &= \operatorname*{argmin}_X \left\{ \|Y - A\Omega^{1/2}X\|_2^2 + \lambda \|X\|_2^2 \right\}, \end{aligned} \tag{18.24}$$

其中 A 是经尺度归一化的单位方差高斯矩阵。

如何求解？可映射到前一个问题。先考虑 AMP，作一个看似简单的替换：等价地最小化

$$\widehat{W} = \operatorname*{argmin}_W \left\{ \|Y - AW\|_2^2 + \lambda W\Omega^{-1}W \right\}. \tag{18.25}$$

这是标准岭回归，但近端函数变为

$$f_t(u) = \Omega\big(\lambda/(\alpha-b) + \Omega\big)^{-1}u, \tag{18.26}$$

$$b = \operatorname{Tr} \frac{1}{p}\Omega\big(\lambda/(\alpha-b)+\Omega\big)^{-1}. \tag{18.27}$$

使用变量替换

$$\alpha - b = \widehat{V} = \frac{\alpha}{1+V}, \tag{18.28}$$

便得到

$$f_t(u) = \widehat{V}\Omega(\lambda + \Omega\widehat{V})^{-1}u, \tag{18.29}$$

$$\widehat{V} = \frac{\alpha}{1+V}, \tag{18.30}$$

$$V = \Omega(\lambda + \Omega\widehat{V})^{-1}. \tag{18.31}$$

其次，u, v 可写成两个纯高斯向量的混合：

$$u = (1 - \Phi\Omega^{-1}\Phi)^{1/2}z + \Phi\Omega^{-1/2}z', \tag{18.32}$$

$$v = \Omega^{1/2}z'. \tag{18.33}$$

从 z' 的角度看，教师标签 y 只依赖如下投影的 oracle 权重（$\gamma = d/p$）：

$$w^* = \frac{1}{\sqrt{\gamma}}\Omega^{-1/2}\Phi^T\theta^*. \tag{18.34}$$

也就是说，对学生而言生成模型等价于 $z' \cdot w^* +$ 噪声。

据此修改状态演化。定义 $\rho = \mathbb{E}[y^2]$、$E = \rho + q - 2m$，前面的方程保持不变：

$$\begin{aligned} q_u^{t+1} &= \alpha\mathbb{E}[(g_t^{\text{out}}(\omega, \phi(z_0)))^2] = \alpha\mathbb{E}[(y-w)^2] = \alpha(\rho + q_\omega - 2m_\omega + \Delta) \\ &= \alpha(E^t + \Delta), \end{aligned} \tag{18.35}$$

$$m_u^{t+1} = \alpha\mathbb{E}[\partial_{z_0}(g_t^{\text{out}}(\sqrt{q_\omega^t}Z' + m_\omega^t z_0, \phi(z_0)))] = \alpha, \tag{18.36}$$

$$\tag{18.37}$$

接下来的方程则需小心：仍有 $u \sim \sqrt{q_u}Z + m_u W^*$，而 $W^* = \gamma^{-1/2}\Omega^{-1/2}\Phi^T\theta^*$，所以

$$q_\omega^t = \mathbb{E}\left[e_t^{\text{in}}\left(\sqrt{q_u^t}Z + + m_u^t\frac{1}{\sqrt{\gamma}}\Omega^{-1/2}\Phi^T\theta^*\right)^2\right], \tag{18.38}$$

$$m_\omega^t = \mathbb{E}\left[e_t^{\text{in}}\left(\sqrt{q_u^t}Z + m_u^t\frac{1}{\sqrt{\gamma}}\Omega^{-1/2}\Phi^T\theta^*\right)\frac{1}{\sqrt{\gamma}}\Omega^{-1/2}\Phi\theta^{*T}\right]. \tag{18.39}$$

这些方程给出

$$m = \frac{1}{p\gamma}\widehat{V}\operatorname{Tr}[(\lambda + \Omega\widehat{V}))^{-1}\Phi^T\theta^*\theta^{*T}\Phi],$$

以及

$$q = \frac{1}{p}\widehat{V}^2\operatorname{Tr}\left[(\lambda+\Omega\widehat{V})^{-2}\left(\Omega\frac{1}{\gamma}\Phi^T\theta^*\theta^{*T}\Phi + \alpha(E+\Delta)\Omega\,.\right)\right].$$

译注： 源协方差块的 1、惩罚 $W\Omega^{-1}W$ 缺转置、式 (18.31) 的矩阵右端与标量 V、式 (18.32) 的 Φ 转置和条件协方差维度，均需核对，按原式保留。$u/v/U/W$、$\theta^*/\theta^\star$ 及缩放约定也未自行统一；原文没有在此给出 Ω 可逆性等完整条件。式 (18.37) 为原空编号，(18.38) 的双加号、(18.39) 末尾的 $\Phi\theta^{*T}$、最后两式的多余右括号和点亦照录。标题的 “精确渐近” 是源文标题，不能以本轮编译通过认证这些未经澄清的公式。

第五部分：附录

19 一点概率论

等等，如果我能甩掉期望那沉重的压力，

是否就能腾出些空间给快乐？给放松？

或者给简单的乐趣？可是，我们却只顾测量！

Lin-Manuel Miranda，《Surface Pressure》，《Encanto》，2021

译注：原文第 19 章仅有章名和题辞，没有正文；译本保留该状态。

参考文献

保留原书目语言与出版信息，供检索核对；未对各条目另作外部书目认证。原 Debye 条目的年份为 1009，按源保留。

Abbe, E. and Montanari, A. (2013). Conditional random fields, planted constraint satisfaction and entropy concentration. In Approximation, Randomization, and Combinatorial Optimization. Algorithms and Techniques, pages 332–346. Springer.

Achlioptas, D. and Coja-Oghlan, A. (2008). Algorithmic barriers from phase transitions. In 2008 49th Annual IEEE Symposium on Foundations of Computer Science, pages 793–802. IEEE.

Achlioptas, D. and Moore, C. (2003). Almost all graphs with average degree 4 are 3-colorable. Journal of Computer and System Sciences, 67(2):441–471.

Aizenman, M., Sims, R., and Starr, S. L. (2003). Extended variational principle for the sherrington-kirkpatrick spin-glass model. Physical Review B, 68(21):214403.

Aubin, B., Loureiro, B., Maillard, A., Krzakala, F., and Zdeborová, L. (2020). The spiked matrix model with generative priors. IEEE Transactions on Information Theory.

Bai, Z. and Silverstein, J. W. (2010). Spectral analysis of large dimensional random matrices, volume 20. Springer.

Baik, J., Arous, G. B., Péché, S., et al. (2005). Phase transition of the largest eigenvalue for nonnull complex sample covariance matrices. Annals of Probability, 33(5):1643–1697.

Barbier, J., Dia, M., Macris, N., Krzakala, F., Lesieur, T., and Zdeborová, L. (2016). Mutual information for symmetric rank-one matrix estimation: A proof of the replica formula. arXiv preprint arXiv:1606.04142.

Barbier, J. and Macris, N. (2019). The adaptive interpolation method: a simple scheme to prove replica formulas in bayesian inference. Probability theory and related fields, 174(3):1133–1185.

Bayati, M. and Montanari, A. (2011). The dynamics of message passing on dense graphs, with applications to compressed sensing. IEEE Transactions on Information Theory, 57(2):764–785.

Berthier, R., Montanari, A., and Nguyen, P.-M. (2020). State evolution for approximate message passing with non-separable functions. Information and Inference: A Journal of the IMA, 9(1):33–79.

Bethe, H. A. (1935). Statistical theory of superlattices. Proceedings of the Royal Society of London. Series A-Mathematical and Physical Sciences, 150(871):552–575.

Bolthausen, E. (2009). On the high-temperature phase of the sherrington-kirkpatrick model. In Seminar at EURANDOM, Eindhoven.

Bolthausen, E. (2014). An iterative construction of solutions of the tap equations for the sherrington–kirkpatrick model. Communications in Mathematical Physics, 325(1):333–366.

Boucheron, S., Lugosi, G., and Massart, P. (2013). Concentration inequalities: A nonasymptotic theory of independence. Oxford university press.

Braunstein, A., Dall' Asta, L., Semerjian, G., and Zdeborová, L. (2016). The large deviations of the whitening process in random constraint satisfaction problems. Journal of Statistical Mechanics: Theory and Experiment, 2016(5):053401.

Chertkov, M. (2008). Exactness of belief propagation for some graphical models with loops. Journal of Statistical Mechanics: Theory and Experiment, 2008(10):P10016.

Chertkov, M. and Chernyak, V. Y. (2006). Loop series for discrete statistical models on graphs. Journal of Statistical Mechanics: Theory and Experiment, 2006(06):P06009.

Coja-Oghlan, A. (2013). Upper-bounding the k-colorability threshold by counting covers. arXiv preprint arXiv:1305.0177.

Coja-Oghlan, A., Krzakala, F., Perkins, W., and Zdeborová, L. (2018). Information-theoretic thresholds from the cavity method. Advances in Mathematics, 333:694–795.

Coja-Oghlan, A. and Vilenchik, D. (2013). Chasing the k-colorability threshold. In 2013 IEEE 54th Annual Symposium on Foundations of Computer Science, pages 380–389. IEEE.

Cover, T. M. and Thomas, J. A. (1991). Information theory and statistics. Elements of Information Theory, 1(1):279–335.

Curie, P. (1895). Propriétés magnétiques des corps a diverses températures. Number 4. Gauthier-Villars et fils.

de Almeida, J. R. and Thouless, D. J. (1978). Stability of the sherrington-kirkpatrick solution of a spin glass model. Journal of Physics A: Mathematical and General, 11(5):983.

Debye, P. (1009). Näherungsformeln für die zylinderfunktionen für große werte des arguments und unbeschränkt veränderliche werte des index. Math. Ann., 67:535–558.

Dembo, A., Montanari, A., et al. (2010a). Gibbs measures and phase transitions on sparse random graphs. Brazilian Journal of Probability and Statistics, 24(2):137–211.

Dembo, A., Montanari, A., et al. (2010b). Ising models on locally tree-like graphs. The Annals of Applied Probability, 20(2):565–592.

Dembo, A., Montanari, A., Sly, A., and Sun, N. (2014). The replica symmetric solution for potts models on d-regular graphs. Communications in Mathematical Physics, 327(2):551–575.

Dembo, A., Zeltouni, O., and Fleischmann, K. (1996). Large deviations techniques and applications. Jahresbericht der Deutschen Mathematiker Vereinigung, 98(3):18–18.

Derrida, B. (1980). Random-energy model: Limit of a family of disordered models. Physical Review Letters, 45(2):79.

Derrida, B. (1981). Random-energy model: An exactly solvable model of disordered systems. Physical Review B, 24(5):2613.

Donoho, D. L., Johnstone, I. M., et al. (1998). Minimax estimation via wavelet shrinkage. The annals of Statistics, 26(3):879–921.

Donoho, D. L., Maleki, A., and Montanari, A. (2009). Message-passing algorithms for compressed sensing. Proceedings of the National Academy of Sciences, 106(45):18914–18919.

Edwards, S. F., Goldbart, P. M., Goldenfeld, N., Sherrington, D. C., and Edwards, S. F., editors (2005). Stealing the gold: a celebration of the pioneering physics of Sam Edwards. Number 126 in International series of monographs on physics. Clarendon Press ; Oxford University Press, Oxford : New York.

Edwards, S. F. and Jones, R. C. (1976). The eigenvalue spectrum of a large symmetric random matrix. Journal of Physics A: Mathematical and General, 9(10):1595.

El Alaoui, A. and Krzakala, F. (2018). Estimation in the spiked wigner model: A short proof of the replica formula. In 2018 IEEE International Symposium on Information Theory (ISIT), pages 1874–1878. IEEE.

Gallager, R. (1962). Low-density parity-check codes. IRE Transactions on information theory, 8(1):21–28.

Gerbelot, C. and Berthier, R. (2021). Graph-based approximate message passing iterations. arXiv preprint arXiv:2109.11905.

Gross, D. J. and Mézard, M. (1984). The simplest spin glass. Nuclear Physics B, 240(4):431–452.

Guerra, F. (2003). Broken replica symmetry bounds in the mean field spin glass model. Communications in mathematical physics, 233(1):1–12.

Guo, D., Shamai, S., and Verdú, S. (2005). Mutual information and minimum mean-square error in gaussian channels. IEEE transactions on information theory, 51(4):1261–1282.

Iba, Y. (1999). The nishimori line and bayesian statistics. Journal of Physics A: Mathematical and General, 32(21):3875.

Jaeger, G. (1998). The ehrenfest classification of phase transitions: Introduction and evolution. Arch Hist Exact Sc., 53:51–81.

Johnstone, I. M. (2001). On the distribution of the largest eigenvalue in principal components analysis. Annals of statistics, pages 295–327.

Kadanoff, L. P. (2009). More is the same; phase transitions and mean field theories. Journal of Statistical Physics, 137(5):777–797.

Kesten, H. and Stigum, B. P. (1967). Limit theorems for decomposable multi-dimensional galton-watson processes. Journal of Mathematical Analysis and Applications, 17(2):309–338.

Korada, S. B. and Macris, N. (2009). Exact solution of the gauge symmetric p-spin glass model on a complete graph. Journal of Statistical Physics, 136(2):205–230.

Krzakala, F., Mézard, M., Sausset, F., Sun, Y., and Zdeborová, L. (2012). Probabilistic reconstruction in compressed sensing: algorithms, phase diagrams, and threshold achieving matrices. Journal of Statistical Mechanics: Theory and Experiment, 2012(08):P08009.

Krzakala, F., Xu, J., and Zdeborová, L. (2016). Mutual information in rank-one matrix estimation. In 2016 IEEE Information Theory Workshop (ITW), pages 71–75. IEEE.

Laplace, P. S. d. (1774). Memoire sur les probabilites des causes par lesevenements.

Lelarge, M. and Miolane, L. (2019). Fundamental limits of symmetric low-rank matrix estimation. Probability Theory and Related Fields, 173(3):859–929.

Lesieur, T., Krzakala, F., and Zdeborová, L. (2017). Constrained low-rank matrix estimation: Phase transitions, approximate message passing and applications. Journal of Statistical Mechanics: Theory and Experiment, 2017(7):073403.

Livan, G., Novaes, M., and Vivo, P. (2018). Introduction to random matrices: theory and practice, volume 26. Springer.

McGrayne, S. B. (2011). The theory that would not die. Yale University Press.

Mézard, M. and Parisi, G. (1999). Thermodynamics of glasses: A first principles computation. Journal of Physics: Condensed Matter, 11(10A):A157.

Mézard, M. and Parisi, G. (2001). The bethe lattice spin glass revisited. The European Physical Journal B-Condensed Matter and Complex Systems, 20(2):217–233.

Mézard, M. and Parisi, G. (2003). The cavity method at zero temperature. Journal of Statistical Physics, 111(1):1–34.

Mézard, M., Parisi, G., Sourlas, N., Toulouse, G., and Virasoro, M. (1984). Nature of the spin-glass phase. Physical review letters, 52(13):1156.

Mézard, M., Parisi, G., and Virasoro, M. (1987a). Sk model: The replica solution without replicas. SPIN GLASS THEORY AND BEYOND: AN INTRODUCTION TO THE REPLICA METHOD AND ITS APPLICATIONS. Edited by MEZARD M ET AL. Published by World Scientific Press, pages 232–237.

Mézard, M., Parisi, G., and Virasoro, M. A. (1987b). Spin glass theory and beyond: An Introduction to the Replica Method and Its Applications, volume 9. World Scientific Publishing Company.

Mézard, M., Parisi, G., and Zecchina, R. (2002). Analytic and algorithmic solution of random satisfiability problems. Science, 297(5582):812–815.

Miolane, L. (2017). Fundamental limits of low-rank matrix estimation: the non-symmetric case. arXiv preprint arXiv:1702.00473.

Monasson, R. (1995). Structural glass transition and the entropy of the metastable states. Physical review letters, 75(15):2847.

Nattermann, T. (1998). Theory of the random field ising model. In Spin glasses and random fields, pages 277–298. World Scientific.

Nishimori, H. (1980). Exact results and critical properties of the ising model with competing interactions. Journal of Physics C: Solid State Physics, 13(21):4071.

Nishimori, H. (1993). Optimum decoding temperature for error-correcting codes. Journal of the Physical Society of Japan, 62(9):2973–2975.

Opper, M. and Saad, D. (2001). Advanced mean field methods: Theory and practice. MIT press.

Parisi, G. (1979). Infinite number of order parameters for spin-glasses. Physical Review Letters, 43(23):1754.

Parisi, G. (1980). A sequence of approximated solutions to the sk model for spin glasses. Journal of Physics A: Mathematical and General, 13(4):L115.

Parisi, G. (1983). Order parameter for spin-glasses. Physical Review Letters, 50(24):1946.

Pearl, J. (1982). Reverend Bayes on inference engines: A distributed hierarchical approach. Cognitive Systems Laboratory, School of Engineering and Applied Science . . . .

Peierls, R. (1936). Statistical theory of adsorption with interaction between the adsorbed atoms. In Mathematical Proceedings of the Cambridge Philosophical Society, volume 32, pages 471–476. Cambridge University Press.

Potters, M. and Bouchaud, J.-P. (2020). A First Course in Random Matrix Theory: For Physicists, Engineers and Data Scientists. Cambridge University Press.

Rangan, S. (2011). Generalized approximate message passing for estimation with random linear mixing. In 2011 IEEE International Symposium on Information Theory Proceedings, pages 2168–2172. IEEE.

Rangan, S. and Fletcher, A. K. (2012). Iterative estimation of constrained rank-one matrices in noise. In 2012 IEEE International Symposium on Information Theory Proceedings, pages 1246–1250. IEEE.

Ruozzi, N. (2012). The bethe partition function of log-supermodular graphical models. Advances in Neural Information Processing Systems, 25.

Saade, A., Krzakala, F., and Zdeborová, L. (2017). Spectral bounds for the ising ferromagnet on an arbitrary given graph. Journal of Statistical Mechanics: Theory and Experiment, 2017(5):053403.

Schwarz, A., Bluhm, J., and Schröder, J. (2020). Modeling of freezing processes of ice floes within the framework of the tpm. Acta Mechanica, 231.

Shannon, C. E. (1948). A mathematical theory of communication. The Bell system technical journal, 27(3):379–423.

Taillefer, L. (2010). Scattering and pairing in cuprate superconductors. Annual Review of Condensed Matter Physics, 1.

Thouless, D. J., Anderson, P. W., and Palmer, R. G. (1977). Solution of ' solvable model of a spin glass' . Philosophical Magazine, 35(3):593–601.

Touchette, H. (2009). The large deviation approach to statistical mechanics. Physics Reports, 478(1):1–69.

Wainwright, M. J. and Jordan, M. I. (2008). Graphical models, exponential families, and variational inference. Now Publishers Inc.

Watkin, T. L. H., Rau, A., and Biehl, M. (1993). The statistical mechanics of learning a rule. Reviews of Modern Physics, 65(2):499–556.

Weiss, P. (1907). L' hypothèse du champ moléculaire et la propriété ferromagnétique. J. Phys. Theor. Appl., 6(1):661–690.

Weiss, P. (1948). The application of the bethe-peierls method to ferromagnetism. Physical Review, 74(10):1493.

Wigner, E. P. (1958). On the distribution of the roots of certain symmetric matrices. Annals of Mathematics, pages 325–327.

Willsky, A., Sudderth, E., and Wainwright, M. J. (2007). Loop series and bethe variational bounds in attractive graphical models. Advances in neural information processing systems, 20.

Yedidia, J. S., Freeman, W. T., Weiss, Y., et al. (2003). Understanding belief propagation and its generalizations. Exploring artificial intelligence in the new millennium, 8(236-239):0018–9448.

Zdeborová, L. and Krzakala, F. (2016). Statistical physics of inference: thresholds and algorithms. Advances in Physics, 65(5):453–552.

待办清单

译注：原 PDF 末页仅有 “Todo list” 标题，无条目；保留为空。