从统计学习到因果学习

From statistical to causal learning

Bernhard Schölkopf　Julius von Kügelgen

本地中文审校版

国际数学家大会文集第 7 卷 · EMS Press · 2022
Model: 初译模型未核实；本轮审校 gpt-6.1-sol（high）
审核：曹溪能
Updated: 2026-11-04

摘要

本文介绍构建和理解人工智能系统的研究所依托的基本思想：从符号方法，经由统计学习，到依赖因果概念的干预模型。机器学习与人工智能中的一些困难的开放问题与因果性有着内在联系；要取得进展，可能需要增进我们对如何从数据中对因果关系进行建模和推断的理解。

2020 数学学科分类：主要分类 68T05；次要分类 68Q32、68T01、68T10、68T30、68T37。

关键词：因果推断，机器学习。

原文 © 2022 International Mathematical Union；发表于 *Proceedings of the International Congress of Mathematicians 2022* 第 7 卷，第 5540–5593 页，DOI: 10.4171/ICM2022/173；由 EMS Press 出版，采用 CC BY 4.0 许可。

译本说明：本地中文译本对原作进行翻译、重排并添加明确标识的译注；原文疑点照录并在相关处说明。初译模型无法可靠核实，本轮独立审校为 gpt-6.1-sol（high）。封面审核署名遵循项目格式，不表示人类本人已完成审阅；第三方图像的独立权利与公开发布尚待另行处理。

1 引言

1958 年，《纽约时报》报道了一种称为感知机的新机器。它的发明者 Frank Rosenblatt 展示了感知机能够从经验中学习。他预测，后来的感知机将能够识别人，或者即时翻译口语。如今这些已成为现实，但当时听起来一定像遥远的科幻。回过头看，我们可以把它视为机器学习的诞生；机器学习是推动当前人工智能（AI）大部分进展的领域。

大约在同一时期，另一项同样具有革命性的发展发生了：科学家认识到计算机不仅能够计算数字，还能够处理符号。虽然这一认识也受到人工智能的激励，但回过头看，这是计算机科学领域的诞生。当时人们非常乐观，认为在由人编写的程序中，按照人设计的规则操纵符号，应该足以产生智能。下文中，我们将其称为*符号–规则假说*。[1]

起初，在自动定理证明和计算机国际象棋等看似困难的问题上取得了令人鼓舞的进展。该领域的奠基人之一 Herb Simon 在 1956 年预测："二十年内，机器将能够做一个人能做的任何工作。"然而，看似简单的问题，例如动物能够做的大多数事情，却被证明十分困难。这后来被称为 Moravec 悖论。1997 年，IBM 的深蓝国际象棋计算机击败 Garry Kasparov 时，比赛中与 Kasparov 实际面对面的是一名人类：深蓝能够以前所未有的细致程度分析棋局的搜索树，却不能识别棋子并实际移动它们，因此这项任务不得不交给人来做，形成了对著名的机械土耳其人[2]的颠倒。

在随后的岁月中，人工智能领域进入了后来被称作人工智能寒冬的时期。由于缺少进展和前景，研究群体的幻想破灭，人们的兴趣急剧下降。然而，在很大程度上独立于经典人工智能领域，机器学习最终开始蓬勃发展。与 Rosenblatt 的早期工作一样，它建立在这样一个观察之上：现有的一切真正智能系统的例子——包括人在内的动物——都不是建立在符号–规则假说之上：自然智能系统所实现的表征和规则，都是通过进化与学习过程从经验中获得的。

我们将不去探讨基于规则的方法与基于学习的方法之间众所周知的二分，而是讨论较少为人熟悉的因果性和干预问题。计算机科学中的因果性领域最初与经典人工智能联系紧密，近年来，人们对将其与机器学习相联系产生了浓厚兴趣 [111]。下文将借鉴文献 [125, 133]，探讨其中的一些联系。我们将论证，在处理机器学习中与稳健性以及超出训练分布的泛化概念有关的关键开放问题时，因果视角是相关的。

概述。 在统计学习中，我们的出发点是生成可观测数据的联合分布 $p(X)$。这里 X 是一个随机向量，通常给定的数据集 $x_1, \dots, x_m$ 从 p 中独立同分布地抽取。我们经常关心估计给定 X 的某些分量时其他分量的条件分布的性质，例如分类器（可以通过对条件分布以 0.5 为阈值来得到）。这是一个非平凡的逆问题，由此产生了统计学习理论（第 2 节）。

因果学习的动机来自统计学习的不足（第 3 节）。其出发点是结构因果模型（SCM） [104]（第 4 节）。在 SCM 中，X 的各分量 $X_1, \dots, X_n$ 与有向图的顶点对应，图中的箭头表示直接因果影响。每个顶点都有一个随机变量 U_i，以及一个函数 f_i，后者由其图中的父节点 PA_i 和 U_i 计算 X_i，即

$$X_i := f_i(\mathrm{PA}_i, U_i). \tag{1.1}$$

[1] 这个术语需要有所保留地理解，因为它暗示表征与计算可以分离，而在实践中这种分离很难成立。

[2] `https://en.wikipedia.org/wiki/Mechanical_Turk`。

给定各 U_i 的分布，并假定它们相互独立，这同样产生一个概率模型 $p(X)$。然而，式 (1.1) 中的模型具有更多结构：图的连接关系和函数 f_i 在可观测变量之间产生特定的依赖关系。此外，它描述了系统在干预下如何表现：通过用常数替换函数，我们可以计算将某些变量设定为特定值的效果。

因果学习建立在与标准机器学习不同的假设之上（第 5 节），并处理建模层级中的不同层次（第 6 节）。它也带来一些新问题，如因果发现：我们试图从数据中推断图与函数的性质（第 7 节）。在某些情况下，X_i 之间的条件独立性包含关于图的信息 [144]；但新的假设使我们能够处理某些以前无法解决的情形 [68]。这些假设对半监督学习、协变量偏移适应和迁移学习等机器学习任务有着非平凡的影响 [128]（第 8 节）。一旦获得因果模型，因果推理（第 9 节）就使我们能够从观测数据中识别和估计某些感兴趣的因果查询。最后，我们列出一些当前问题和开放问题（第 10 节），尤其关注因果表征学习。

本文的表述和记号在若干方面会较为非正式。我们通常假设所有分布都具有密度（相对于适当的参考测度）。我们有时用 $p(x)$ 表示随机变量 X 的分布（或密度）。相应地，同一个 p 可以表示另一个分布 $p(y)$，它们通过 $p(\cdot)$ 的自变量加以区分。我们有时还使用求和进行边缘化，这假定变量是离散的；对于连续量，相应的表达式将使用积分。

2 统计学习理论

假设我们测量了两个统计相关的可观测量，并发现这些点大致位于一条直线上。经验科学家或许愿意提出相应的自然规律假说（见图 1）。然而，Leibniz 早已指出，如果摇动羽毛笔在一张纸上随机洒下墨点，我们同样可以找到这些点满足的数学方程 [81]。他认为，我们不会把它称为自然规律，因为无论这些点如何分布，这样的方程总是存在；只有方程简单时，我们才会称它为自然规律。这就提出了一个问题：什么使一个方程简单？物理学家 Rutherford 持一种务实的看法，认为如果存在规律，它就应当直接从数据中显现出来："如果你的实验需要统计，你本应把实验做得更好。" [3] 面对那些规律一目了然的低维推断问题时，这种看法或许是有益的；然而，现代人工智能面对的推断问题更加困难：它们往往是高维且非线性的，而我们对其背后的规律可能几乎没有先验知识（例如，对于医学数据，我们通常没有机制模型）。

统计学习理论研究的是：如果我们拥有足够大的数据集和处理这些数据所需的计算手段，如何仍然能够进行有效推断。让我们借助文献 [130]，看看最简单的学习情形下的一些理论结果；详情见文献 [153]。假设给定经验观测

$$(x_1, y_1), \ldots, (x_m, y_m) \in \mathcal{X} \times \mathcal{Y}, \tag{2.1}$$

其中 $\mathcal{X}$ 是输入所属的某个非空集合，$\mathcal{Y} = \{\pm 1\}$ 是输出集合，在此仅包含两个类别。这种情形称为模式识别。我们的目标是利用训练数据 (2.1) 推断一个函数 $f : \mathcal{X} \to \{\pm 1\}$（从事先选择的某个函数类中选取），使它对此前可能没有见过的新输入 x 给出正确输出。为了形式化 "正确" 的含义，我们假设所有观测 (x_i, y_i) 都是通过一个由未知概率分布 $p(x, y)$ 描述的随机实验独立生成的；这称为独立同分布（i.i.d.）数据情形。我们的目标是最小化期望误差（或风险）

$$R[f] = \int_{\mathcal{X}\times\mathcal{Y}} c(y, f(x))\, dp(x, y), \tag{2.2}$$

[3] 转引自 http://www.warwick.ac.uk/statsdept/staff/JEHS/data/jehsquot.pdf。

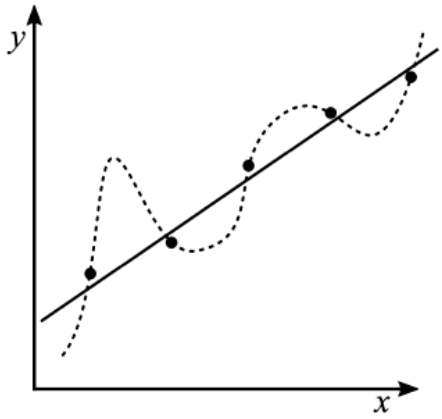


图 1: 给定少量观测，我们如何找到其背后的规律？Leibniz 认为，即使我们随机生成一组点，也总能找到这些点所满足的数学方程。

其中 c 是所谓的损失函数，例如误分类误差 $c(y, f(x)) = \frac{1}{2}|f(x) - y|$；当 $f(x) = y$ 时它取值 0，否则取值 1。

任务的困难在于，我们试图最小化一个无法求值的量：由于不知道 p，我们无法计算式 (2.2)。然而，我们确实知道从 p 中抽取的训练数据 (2.1)。因此，我们可以尝试从训练样本推断一个风险接近式 (2.2) 最小值的函数 f。为此，我们需要所谓的归纳原则。

一种做法是用训练样本以有限和来近似式 (2.2)，称为经验风险：

$$R_{\text{emp}}[f] = \frac{1}{m} \sum_{i=1}^{m} c(x_i, y_i, f(x_i)). \tag{2.3}$$

经验风险最小化（ERM）归纳原则建议我们选择（或“学习”）使式 (2.3) 最小的 f。我们于是可以问，ERM 原则在统计上是否相合：在数据点数趋于无穷的极限下，ERM 是否会得到一个解，使其在未来由 p 生成的数据上达到尽可能好的表现？

事实表明，如果我们对式 (2.3) 求最小值的函数类过大，那么 ERM 就不相合。因此，需要适当地限制可能的函数类。例如，只要函数类的 VC 维有限，ERM 对所有概率分布都是相合的。VC 维是容量度量的一个例子，定义为能够用该函数类中的函数以所有可能方式分离（分类）的最大点数。例如，在 $\mathbb{R}^2$ 上使用线性分类器（以直线分离类别），对于适当选择的 3 个点，我们可以实现所有可能的分类；但一旦有 4 个点，不论它们如何放置，我们都不能再做到这一点（见图 2）。这意味着这个函数类的 VC 维为 3。更一般地，在 $\mathbb{R}^d$ 中，线性分离的 VC 维为 $d + 1$。

只要 VC 维有限，我们的函数（或解释）类就变得可以证伪：从某个观测数量开始，不再能够解释这些点所有可能的标记方式（参见图 2）。因此，如果我们仍然能够解释一个足够大的观测数据集，就有理由相信这是一个有意义的发现。

机器学习的很多研究关注对函数类施加限制以使推断成为可能：可以在函数类上施加先验分布，采用其他约束，或设计自正则化的学习过程，例如用于神经网络的梯度下降方法 [79]。尽管我们对上述监督机器学习（即从输入–输出样本中学习函数）有着扎实的理论理解，但仍有一些细节在研究之中，例如近来观察到的“双重下降”现象 [7]。

支持向量机（SVM）[130, 153] 所采用的一种常见约束是考虑具有大间隔的线性分离：事实表明，对于高维（或无穷维）空间中的大间隔分离，其容量可以远小于维数，从而使得在原本会

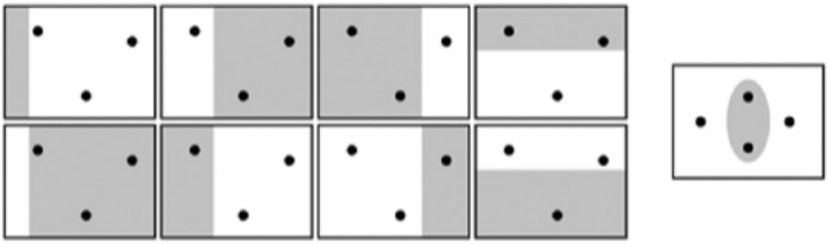


图 2: 使用直线，我们能够以所有可能的方式分离三个点；不论四个点如何放置，都不能做到这一点。线性分离函数类无法用三个点“证伪”，但当点数达到四个或更多时就能够被证伪。

失败的情形下学习成为可能。

对某些学习算法，包括支持向量机和最近邻分类器，存在强普适相合性结果，保证对于任何待学习问题，算法都收敛到能够达到的最低风险 [28, 130, 146, 153]。但请注意，这种收敛可以任意慢。

给定样本量时，我们是否能达到较低的期望误差，取决于所学习的问题。除了渐近相合性陈述，学习理论还给出有限样本量的陈述：可以证明，以至少 $1-\delta$ 的概率（$\delta>0$），对于 VC 维为 h 的某个函数类中的所有函数 f，都有

$$R[f] \le R_{\mathrm{emp}}[f] + \sqrt{\frac{1}{m}\left(h\big(\log(2m/h)+1\big) + \log\frac{4}{\delta}\right)}. \tag{2.4}$$

这是将训练误差 $R_{\mathrm{emp}}[f]$ 与测试误差 $R[f]$ 联系起来的一类结果的例子，其中置信区间（平方根项）依赖函数类的某种容量度量（此处为 VC 维 h）。它表明，当右侧两项都较小时，由未知概率分布生成的未来观测上的期望误差 $R[f]$ 以高概率较小：这两项分别是训练误差 $R_{\mathrm{emp}}[f]$（即我们已经见过的样本上的误差）和平方根项。只要容量 h 与训练观测数量 m 相比足够小，平方根项就小。另一方面，如果我们试图学习一个可能没有意义的东西，例如从人名到电话号码的映射，就会发现，为了解释所有训练数据（即得到较小的 $R_{\mathrm{emp}}[f]$），我们需要容量 h 很大的模型，于是第二项就会变大。无论如何，对于相合性结果和式 (2.4) 这样的有限样本误差界，数据独立同分布这一点都至关重要。

核方法。 设 $\mathcal{X}$ 是非空集合，若对任意点 $x_1,\dots,x_m\in\mathcal{X}$ 和系数 $a_1,\dots,a_m\in\mathbb{R}$ 都有

$$\sum_{i,j} a_i a_j k(x_i,x_j) \ge 0,$$

则称对称函数 $k:\mathcal{X}^2\to\mathbb{R}$ 为正定核。若对两两不同的点，蕴含关系 $\sum_{i,j} a_i a_j k(x_i,x_j)=0 \Rightarrow \forall i: a_i=0$ 成立，则称该核严格正定。任意正定核都会诱导一个映射

$$\Phi : x \mapsto k(x,\cdot), \tag{2.5}$$

它映入再生核 Hilbert 空间（RKHS）$\mathcal{H}$，该空间对于所有 $x,x'\in\mathcal{X}$ 满足

$$\langle k(x,\cdot), k(x',\cdot)\rangle = k(x,x'). \tag{2.6}$$

尽管 $\mathcal{H}$ 可能是无穷维的，只要所有计算步骤都用内积表示，我们就可以在 $\mathcal{H}$ 中构造实用的分类算法，因为这些内积可以通过计算核函数值 (2.6) 得到。

在 SVM 算法中，通过适当的 RKHS 正则项，强制类别在 $\mathcal{H}$ 中具有较大的分离间隔，从而限制函数类的容量。可以证明，解具有如下形式：

$$f(x) = \operatorname{sgn}\left(\sum_i \alpha_i k(x_i, x) + b\right), \tag{2.7}$$

其中学习得到的参数 α_i 与 b 是一个凸二次优化问题的解。对于 SVM 以外、更大一类由 RKHS 范数正则化的核算法，其解也有类似的展开式，可以用在训练点处求值的核函数表示 [126]。

在核方法中，核具有对机器学习至关重要的三个作用：它充当数据点之间的相似度量，通过式 (2.5) 诱导线性空间中的表征[4]，并对寻找解所用的函数类进行参数化，参见式 (2.7)。

核均值嵌入。 考虑两组点 $X := \{x_1, \ldots, x_m\} \subseteq \mathcal{X}$ 和 $Y := \{y_1, \ldots, y_n\} \subseteq \mathcal{X}$。我们定义均值映射 μ 为 [130]

$$\mu(X) = \frac{1}{m}\sum_{i=1}^{m} k(x_i, \cdot). \tag{2.8}$$

对于多项式核 $k(x, x') = (\langle x, x'\rangle + 1)^d$，若所有直至 d 阶的经验矩都相同，则 $\mu(X) = \mu(Y)$。对于严格正定核，只有当 $X = Y$ 时均值才相同，因此 μ 是单射 [131]。均值映射还具有其他有趣的性质 [143]；例如，$\mu(X)$ 表示在样本 X 上对函数取均值的运算：

$$\langle \mu(X), f\rangle = \left\langle \frac{1}{m}\sum_{i=1}^{m} k(x_i, \cdot), f \right\rangle = \frac{1}{m}\sum_{i=1}^{m} f(x_i).$$

此外，

$$\begin{aligned}\|\mu(X) - \mu(Y)\| &= \sup_{\|f\|\le 1} |\langle \mu(X) - \mu(Y), f\rangle| \\ &= \sup_{\|f\|\le 1} \left|\frac{1}{m}\sum_{i=1}^{m} f(x_i) - \frac{1}{n}\sum_{i=1}^{n} f(y_i)\right|.\end{aligned}$$

如果 $\mathbb{E}_{x,x'\sim p}[k(x, x')], \mathbb{E}_{x,x'\sim q}[k(x, x')] < \infty$，那么将均值映射定义为

$$\mu : p \mapsto \mathbb{E}_{x\sim p}\big[k(x, \cdot)\big],$$

并用特征核（characteristic kernel）的概念替代严格正定核，上述陈述（包括 μ 的单射性）便可推广至 Borel 测度 p, q [33]。这意味着在 RKHS 中表示概率分布时，我们不会丢失信息。由此，我们可以用 Hilbert 空间的方法处理分布，并构造通过计算内积来分析分布的实用算法。

注意，均值映射 μ 可以看作服从分布 p 的随机变量 x 的矩生成函数 M_p 的推广：

$$M_p(\cdot) = \mathbb{E}_{x\sim p}\big[e^{\langle x, \cdot\rangle}\big].$$

映射 μ 可应用于许多任务，包括计算随机变量的函数 [129]，以及进行同质性检验 [41] 或独立性检验 [43]。后者对因果推断尤其重要：我们可以通过计算联合分布 $p(X, Y)$ 的基于样本的嵌入与其边缘分布之积 $p(X)p(Y)$ 的嵌入之间的距离，构造基于核的独立性检验 [42, 43, 44, 114, 165]；还可以将其推广到条件独立性检验 [33, 100]，而某些因果发现方法需要这种检验（见第 7 节）。

[4]注意，数据定义域 $\mathcal{X}$ 除了是非空集合之外，不必具有任何其他结构。

3 从统计模型到因果模型

依赖独立同分布数据的方法。 在机器学习目前取得成功的情形中 [79]，我们一般（i）拥有大量数据，通常来自模拟或大规模人工标注；（ii）使用高容量的机器学习模型（例如具有许多可调参数的神经网络）；（iii）使用高性能计算。统计学习理论部分解释了近期学习方法的成功：海量数据集使我们能够训练复杂模型，从而解决日益困难的任务。

然而，一个经常被忽视的关键方面是，我们还（iv）假定数据独立同分布。这一假设对于实践中取得良好性能至关重要，也是式 (2.4) 等理论陈述的基础。当面临违反独立同分布假设的问题时，一切保障都不再适用。如果将一个通常能够被高准确率识别的物体置于某种背景中，而在训练集里这一背景可能与该物体的出现负相关，那么视觉系统就可能被严重误导。例如，这样的系统可能无法识别站在海滩上的奶牛。为了在这类情形下成功泛化，我们需要构建这样的系统：它们不只是依赖统计依赖关系，而是对某些违反独立同分布假设时仍稳健的机制进行建模。正如我们将要论证的，因果性为刻画这类稳定机制并推理不同类型的分布偏移提供了一个自然的框架。

相关与因果。 相关不意味着因果，这已是常识。两个广为人知且有启发性的例子，是巧克力消费量与人均诺贝尔奖数量之间的正相关 [91]，以及鹳的繁殖对数与人类出生率之间的正相关 [89]；这两者都无法用直接因果关系作出合理解释。这些例子自然引出下列问题：我们所说的“因果”究竟是什么意思？它与相关有何关系？如果仅有相关还不够，推断因果还需要什么？

这里，我们采用一种基于可操纵性 [159] 和干预 [104] 的因果概念，它已被证明在农业 [161]、计量经济学 [46, 52] 和流行病学 [118] 等领域中有用。

定义 3.1 (因果效应)**.** *如果存在 $x \neq x'$，使得对随机变量 X 进行干预并将其设为 x 后的随机变量 Y 的分布，不同于将 X 设为 x' 之后 Y 的分布，我们就说 X 对 Y 有因果效应。*

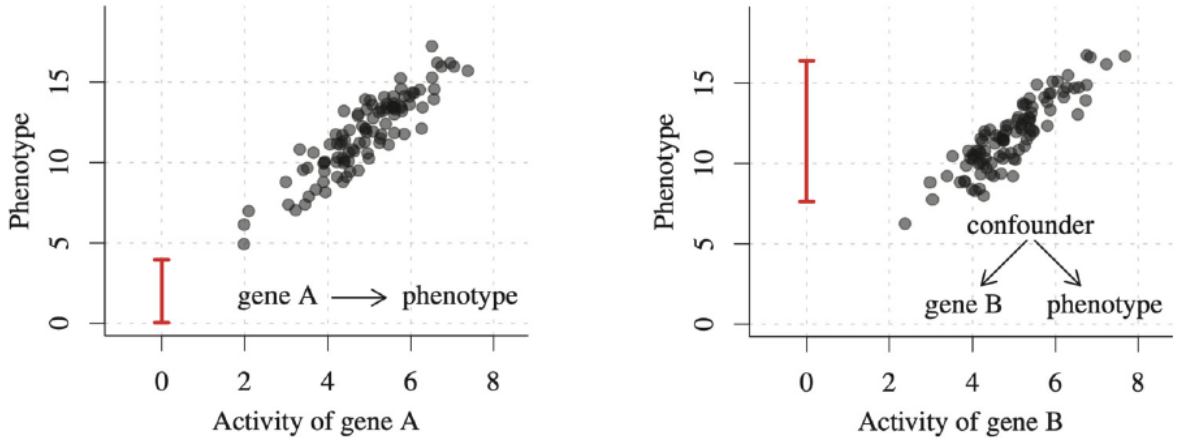
因果概念固有的方向性和不对称性，是相关所不具有的：如果 X 与 Y 相关，那么 Y 与 X 同样相关；但如果 X 对 Y 有因果效应，（在一般情况下）反过来并不成立。

图 3 说明了基于干预的因果概念，以及它与相关（或更一般地，统计依赖）的区别。在这里，两个基因 X_A 和 X_B 基于它们与某个表型 Y 的相关性无法区分，但敲除它们会产生截然不同的效果。只有对 X_A 进行干预才会改变 Y 的分布，而 X_B 对 Y 没有因果效应——它们之间的相关源自另一种含混杂因素的因果结构。这类因果关系通常以因果图表示，其中有向箭头表示直接因果效应。

图 3 中的例子表明，相同的相关关系可以由多个因果图解释，而这些因果图会给出不同的实验结果，即相关不意味着因果。然而，相关与因果之间存在联系，Reichenbach [116] 将其表述为共同原因原理，见图 4。

原理 3.2 (共同原因)**.** *如果随机变量 X 与 Y 统计依赖 ($X \not\perp\!\!\!\perp Y$)，则存在一个随机变量 Z，它对二者都有因果影响，并解释了二者的全部依赖，也就是说，二者在给定 Z 后条件独立 ($X \perp\!\!\!\perp Y \mid Z$)。特殊情况下，$Z$ 可以与 X 或 Y 重合。*

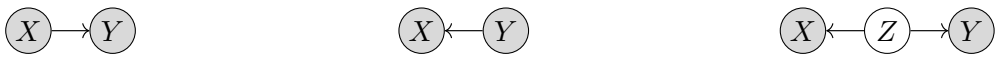
根据原理 3.2，统计依赖总是来自包括可能未观测的变量在内的变量之间相互影响的潜在因果关系。因此，相关是一种伴随现象，是因果过程的副产物。



内嵌因果图的中文重排（保留上方原始散点图）：



图 3: 对两个基因（横轴），基因 A（左）和基因 B（右）的测量，都显示与一个表型（纵轴）有相同的强正相关。然而，仅凭这一统计信息不足以预测将一个基因的活性设为零的敲除实验的结果（$x = 0$ 处的竖线）。回答此类干预问题需要额外的因果知识（内嵌因果图）：敲除作为直接原因的基因 A 会降低表型；敲除与表型具有共同原因或混杂因素、但对表型无因果效应的基因 B，则不会影响表型。这表明相关本身不足以预测对系统施加扰动的结果（示例数据，图源于文献 [111]）。图中横轴分别为基因 A、基因 B 的活性，纵轴为表型；内嵌图中为基因 A 指向表型，以及混杂因素分别指向基因 B 与表型。



(a) (b) (c)

图 4: Reichenbach 的共同原因原理 [116] 认为，随机变量 X, Y 之间的统计依赖有 (a)–(c) 所示的三种基本因果解释。因此，关联总是由潜在的因果过程引起。在 (a) 中共同原因 Z 与 X 重合，在 (b) 中与 Y 重合。灰色节点表示已观测变量，白色节点表示未观测变量。

对于巧克力消费量（X）和诺贝尔奖得主（Y）的例子，常识表明两个变量都不应对另一个有因果效应：无论是巧克力消费推动科学成就（$X \to Y$，图 4(a)），还是诺贝尔奖得主增加巧克力消费（$Y \to X$，图 4(b)），似乎都不合理。于是原理 3.2 告诉我们，所观察到的相关必须由图 4(c) 中的共同原因 Z 解释。这种混杂因素的一个合理候选，例如，可以是同时推动消费支出及教育和科学投资的经济因素。

然而，如果没有这样的背景知识或额外假设，我们无法通过被动观察，即以纯数据驱动的方式，区分图 4 中的三种情况：这些模型能够实现的关于 X 和 Y 的观测分布类在三种情况下相同。

需要明确的是，这并不意味着相关没有用，或总是需要因果洞见。在被动或观测性的情形下，如果我们测量某些基因的活性并被要求预测表型，那么图 3 中的两个基因仍然都是有用的预测特征。类似地，巧克力消费仍然能够预测获得诺贝尔奖。但是，如果我们想回答干预问题，例如基因敲除实验的结果，或强制提高巧克力消费的政策的效果，就需要相关以外的东西：因果模型。

4 因果建模框架

因果推断在统计学、计量经济学、流行病学和人工智能等多个学科中有着悠久历史。因此，多年来出现了不同的因果建模框架，且如今它们同时存在。下文介绍的第一个框架（CGM）从可观测变量的分布出发，将其与有向图结合以赋予其因果语义。第二个框架（SCM）从图和一组函数赋值出发，将观测分布生成为未观测噪声分布的推前。最后，我们介绍统计学中流行的一种非图方法（PO）。

因果图模型（CGM）。 图模型框架 [75, 78] 通过以图的形式编码变量之间的依赖结构，提供了一种紧凑地表示联合概率分布的方法。有向图模型也称为贝叶斯网络 [101]。尽管它们本身并不提供因果解释——事实上，不同图模型可以与同一分布相容（参见原理 3.2）——但当边被赋予直接因果效应的含义（定义 3.1）时，我们就称之为因果图模型（CGM） [144]。

定义 4.1 (CGM)**.** *n 个随机变量 $X_1, \dots, X_n$ 上的 CGM $M = (G, p)$ 包括：(i) 有向无环图 (DAG) G，其中有向边 $X_j \to X_i$ 表示 X_j 对 X_i 的直接因果效应；(ii) 关于 G 满足 Markov 性的联合分布 $p(X_1, \dots, X_n)$：*

$$p(X_1, \dots, X_n) = \prod_{i=1}^{n} p(X_i \mid \mathrm{PA}_i), \tag{4.1}$$

其中 $\mathrm{PA}_i = \{X_j : (X_j \to X_i) \in G\}$ 表示 G 中 X_i 的父节点或直接原因的集合。

我们将式 (4.1) 称为因果（或解缠结）分解。尽管还有许多其他纠缠的分解方式，例如

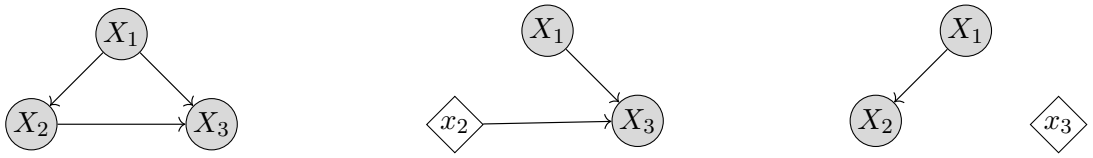
$$p(X_1, \dots, X_n) = \prod_{i=1}^{n} p(X_i \mid X_{i+1}, \dots, X_n), \tag{4.2}$$

但只有式 (4.1) 将联合分布分解为因果条件分布或因果机制 $p(X_i \mid \mathrm{PA}_i)$。这些条件分布可以具有有意义的物理解释，而不是仅仅像式 (4.2) 右侧各因子那样的数学对象。

事实表明，式 (4.1) 等价于以下条件。

定义 4.2 (因果 Markov 条件)**.** *若对于 DAG G 中每个变量，在给定其父节点时，它都与其非后代条件独立，则称分布 p 关于 G 满足因果 Markov 条件。*

定义 4.2 可以等价地用有向图的图论判据 d-分离来表述：G 中的 d-分离蕴含 p 中的（条件）独立性 [104]。因此，因果 Markov 条件将 p 和 G 的性质联系起来。



(a) G (b) G' (c) G''

图 5: (a) 三个变量上的有向无环图 G。具有因果图 G 和观测分布 p 的因果图模型 (G, p) 可以使用图手术回答干预查询：当某变量被干预并设置为常数（白色菱形）时，它不再受其他变量影响，在图中表现为移除所有指向该变量的入边。(b)、(c) 分别给出 $\mathrm{do}(X_2 := x_2)$ 和 $\mathrm{do}(X_3 := x_3)$ 后的图 G' 与 G''。（对 X_1 的干预不会改变图。）

使 CGM 具有因果性质的是将边解释为因果关系。借助 do 算子 [104] 和图手术 [144] 的概念，这使我们能够推理干预的结果。其核心思想是，对一个变量进行干预，例如从外部迫使它取某个特定值，会使它独立于其原因并切断这些原因对它的因果影响，图 5 给出了示意。例如，如果敲除一个基因，它就不再受先前调控它的其他基因影响；其活性现在仅由干预决定。这与条件化有根本区别，因为被动观察基因的活性会提供关于其驱动因素（即直接原因）的信息。

为了强调被动观察与主动干预的区别，Pearl [104] 引入记号 $\mathrm{do}(X := x)$ 表示将变量 X 设为值 x 的干预。“图手术”指这样一种思想：干预的效果可通过修改原图来刻画，即移除指向被干预变量的所有入边。随后可以在修改后的干预后图上进行概率推断以回答干预查询；由于移除了边，这通常会产生额外的（条件）独立性。

例 4.3. *对于图 5 的 CGM，干预分布 $p(X_3 \mid \mathrm{do}(X_2 := x_2))$ 可通过在满足 $X_1 \perp\!\!\!\perp X_2$ 的干预后图 G' 上进行概率推断得到：*

$$p\big(X_3 \mid \mathrm{do}(X_2 := x_2)\big) = \sum_{x_1 \in \mathcal{X}_1} p(x_1) p(X_3 \mid x_1, x_2) \tag{4.3}$$

$$\neq \sum_{x_1 \in \mathcal{X}_1} p(x_1 \mid x_2) p(X_3 \mid x_1, x_2) = p(X_3 \mid x_2). \tag{4.4}$$

它不同于条件分布 $p(X_3 \mid x_2)$；后者在满足 $X_1 \not\perp\!\!\!\perp X_2$ 的原图 G 上进行推断。

注意式 (4.3) 中的边缘分布 $p(x_1)$，与式 (4.4) 中的条件分布 $p(x_1 \mid x_2)$ 不同：这正是干预 $\mathrm{do}(X_2 := x_2)$ 切断的联系，见图 5(b)。式 (4.3) 的右侧是协变量调整的一个例子：它控制了 X_2 对 X_3 因果效应的混杂因素 X_1；有关调整与计算干预的更多细节见第 9 节。

CGM 已广泛用于基于约束与基于评分的因果发现方法 [47, 144]，我们将在第 7 节讨论这些方法。由于概念简单，它们是推理干预的有用且直观的模型。然而，作为因果模型，它们的能力有限，因为它们不支持反事实推理；接下来讨论的两个因果建模框架更适合处理这一问题。

结构因果模型（SCM）。 结构因果模型也称为函数因果模型或非参数结构方程模型，与上面介绍的图方法有关，但它使用有方向的函数性父子关系，而非因果条件分布。尽管回头看这一思想概念简单，它却是理解因果性的一大进步，正如文献 [104, 第 104 页] 后来所说：

> “我们尝试用函数对应式 $X_i = f_i(\mathrm{PA}_i, U_i)$ 替代父子关系 $p(X_i \mid \mathrm{PA}_i)$，突然之间，一切都开始变得明朗起来：我们终于得到了一个数学对象，能够把熟悉的物理机制性质归于它，而不必再使用那些在研究贝叶斯网络时长久以来一直使用的、难以捉摸的认识性概率 $p(X_i \mid \mathrm{PA}_i)$。”

定义 4.4 (SCM)**.** *由 n 个随机变量 $X_1, \ldots, X_n$ 组成的集合 $\mathbf{X}$ 上的 SCM $M = (\mathcal{F}, p_U)$ 包括：(i) 由 n 个赋值（结构方程）组成的集合*

$$\mathcal{F} = \{X_i := f_i(\mathrm{PA}_i, U_i)\}_{i=1}^{n}, \tag{4.5}$$

其中 f_i 是确定性函数，根据其因果父节点 $\mathrm{PA}_i \subseteq \mathbf{X} \setminus \{X_i\}$ 和外生噪声变量 U_i 计算每个变量 X_i；(ii) 外生噪声变量的联合分布 $p_U(U_1, \ldots, U_n)$。

SCM 范式将每个可观测变量 X_i 由其他变量生成的过程 f_i 视为物理机制。所有随机性都来自未观测（也称未解释）的噪声项 U_i；它们既刻画过程可能的随机性，也刻画由于系统中未测量部分带来的不确定性。

还要注意，使用赋值符号 “:=” 代替等号，是为了表示因果关系的不对称性：左侧的量被定义为取右侧的值。例如，我们不能简单地将结构方程 $X_2 := f_2(X_1, U_2)$ 改写为某个 g 对应的 $X_1 = g(X_2, U_2)$，尽管对于普通的（可逆）方程可以这样做。

在参数化的线性形式下（即 f_i 为线性函数时），SCM 也称为结构方程模型，在路径分析 [161] 和经济学 [46, 52] 中有悠久历史。

每个 SCM 都通过结构方程的输入变量诱导一个相应的因果图，这一因果图作为表征很有用，并建立了与 CGM 的联系。

定义 4.5 (诱导因果图)**.** *SCM M 诱导的因果图 G 是以 $\mathbf{X}$ 为顶点集，且对所有 i 从 PA_i 中每个顶点指向 X_i 均有一条有向边的图。*

例 4.6. *考虑 $\mathbf{X} = \{X_1, X_2, X_3\}$ 上、具有某个 $p_U(U_1, U_2, U_3)$ 的 SCM:*

$$X_1 := f_1(U_1), \qquad X_2 := f_2(X_1, U_2), \qquad X_3 := f_3(X_1, X_2, U_3).$$

按照定义 4.5，其诱导图对应图 5 中的 G。

定义 4.4 允许丰富的因果模型类，包括带环的因果关系模型，以及由于噪声项之间复杂的协方差结构而不满足因果 Markov 条件（定义 4.2）的模型。尽管已有关于此类有环或含混杂因素 SCM 的研究 [13]，通常仍会作出以下两个假设。

假设 4.7 (无环性)**.** *诱导图 G 是一个 DAG，即它不包含环。*

假设 4.8 (因果充分性 / 不存在隐藏混杂因素)**.** *U_i 联合独立，即其分布可以分解为*

$$p_U(U_1, \ldots, U_n) = p_{U_1}(U_1) \times \cdots \times p_{U_n}(U_n).$$

假设 4.7 蕴含[5]存在定义良好且唯一的 $\mathbf{X}$ 上的（观测）分布，我们可以通过祖先采样从中抽样：[6]首先从 p_U 中抽取噪声变量，然后按诱导 DAG 的拓扑顺序（即从图的根节点开始）迭代计

[5] 无环性是充分条件，但不是必要条件。

[6] 由于 $\mathcal{F}$ 和 p 事先均未知，祖先采样应被视为一个假设性的采样过程；通常仍有必要进行推断和学习。

算相应的 X_i，在必要时将已计算的 X_i 代入结构方程。形式上，假设 4.7 下由 SCM 诱导的（观测）分布 $p(X_1,\dots,X_n)$，定义为噪声分布 p_U 经由结构方程 $\mathcal{F}$ 的推前。在假设 4.8 下，因果条件分布由下式给出：

$$p(X_i \mid \mathrm{PA}_i = \mathrm{pa}_i) := p_{U_i}\big(f_{\mathrm{pa}_i}^{-1}(X_i)\big), \qquad i = 1,\dots,n, \tag{4.6}$$

其中 $f_{\mathrm{pa}_i}^{-1}(X_i)$ 表示固定 $\mathrm{PA}_i = \mathrm{pa}_i$ 时，X_i 在 f_i 下的原像。

假设 4.8 排除了隐藏混杂因素的存在，因为任何同时影响多个 X_i 的未测量变量都会使某些噪声项之间产生依赖（噪声项涵盖了不能由观测到的 X_i 解释的任何外部或外生影响）。因此，与假设 4.7 结合时，假设 4.8（也称因果充分性）确保 SCM 诱导的分布能够按其诱导因果图分解为式 (4.1) 的形式。换言之，它保证诱导因果图满足因果 Markov 条件 [104]。除非明确另有说明，下文都假定因果充分性。

由于干预与结构方程的赋值性质在概念上相似，干预分布的计算自然地融入 SCM 框架。为了对干预建模，我们只需替换相应的结构方程，并考虑由此得到的分布。

定义 4.9 (SCM 中的干预)**.** *SCM $M = (\mathcal{F}, p_U)$ 中的干预 $\mathrm{do}(X_i := x_i)$，通过将 $\mathcal{F}$ 中第 i 个结构方程替换为 $X_i := x_i$ 来建模，从而得到干预后的 SCM $M_{\mathrm{do}(X_i:=x_i)} = (\mathcal{F}', p_U)$。干预分布 $p(\mathbf{X}_{-i} \mid \mathrm{do}(X_i := x_i))$（其中 $\mathbf{X}_{-i} = \mathbf{X} \setminus \{X_i\}$）和干预图 G' 均由 $M_{\mathrm{do}(X_i:=x_i)}$ 诱导。*

这种处理干预的方式与 CGM 中的方式一致。例如，在例 4.6 中执行 $\mathrm{do}(X_2 := x_2)$ 后，X_1 不再出现在 X_2 的结构方程中，因此边 $X_1 \to X_2$ 在干预图中消失，如图 5 中的 G' 所示。

与 CGM 不同，SCM 还为反事实推理提供了框架。(i) 观察描述被动看到或测得的事物；(ii) 干预描述主动的外部操纵或实验；而（iii）反事实是在实际上观察到其他情况的前提下，关于本来会发生或可能发生什么的陈述。这三种推理方式有时被称为 “因果阶梯” 的三个台阶 [107]。例如，考虑以下反事实查询：

> 已知患者 X 接受治疗 A 后健康状况恶化，如果其他条件相同，该患者改为接受治疗 B，本来会发生什么？

“其他条件相同” 强调了干预与反事实之间的区别：观察到事实结果（即实际发生的事情）提供了有关系统背景状态的信息（在 SCM 中由噪声项刻画），这些信息可以用来推理替代的反事实结果。这不同于无法获得此类背景信息的干预。例如，观察到治疗 A 无效可能告诉我们患者患有一种罕见疾病，因此治疗 B 本来会有效。然而，鉴于已经开具治疗 A，患者的状况可能已经改变，未来再干预时 B 可能不再有效。

注意，根据反事实的定义，它们不能通过经验直接观察，因此不可证伪。有些人因此认为它们不科学 [115]，或至少存在问题 [26]。另一方面，人类似乎确实会在实践中进行反事实推理，并在幼儿期就发展出这种能力 [14]。

在 SCM 中，通过以下三个步骤计算反事实：

1. 根据观测证据将噪声分布更新为其后验分布（“溯因”）。
2. 操纵结构方程以刻画假设的干预（“行动”）。
3. 使用修改后的 SCM 推断感兴趣的量（“预测”）。

定义 4.10 (SCM 中的反事实)**.** 给定从 *SCM* $M = (\mathcal{F}, p_U)$ 观察到的证据 $\mathbf{X} = \mathbf{x}$，通过用后验更新 p_U 得到反事实 *SCM*:

$$M_{\mathbf{X}=\mathbf{x}} = (\mathcal{F}, p_{U|\mathbf{X}=\mathbf{x}}).$$

然后在反事实 *SCM* $M_{\mathbf{X}=\mathbf{x}}$ 中执行干预，计算反事实，见定义 *4.9*。

注意，计算干预只涉及操纵结构方程，而反事实还涉及更新噪声分布，这突出了二者的概念差异。更新 p_U 需要知道噪声与观测变量之间的相互作用，即需要知道结构方程，这解释了为何需要额外的假设。注意，即便原系统是因果充分的（假设 4.8），更新后的噪声变量也不再一定相互独立。

例 4.11 (使用 SCM 计算反事实)**.** 考虑如下定义的 *SCM* M:

$$X := U_X, \qquad Y := 3X + U_Y, \qquad U_X, U_Y \sim \mathcal{N}(0, 1). \tag{4.7}$$

假设我们观测到 $X = 2$、$Y = 6.5$，并希望回答反事实问题 "如果 $X = 1$，Y 本来会是多少？"，即我们关心 $p(Y_{X=1} \mid X = 2, Y = 6.5)$。根据观测证据，通过式 (4.7) 更新噪声后，得到反事实 *SCM* $M_{X=2,Y=6.5}$:

$$X := U_X, \qquad Y := 3X + U_Y, \qquad U_X \sim \delta(2), \qquad U_Y \sim \delta(0.5), \tag{4.8}$$

其中 $\delta(\cdot)$ 表示 *Dirac delta* 测度。随后在式 (4.8) 中执行干预 $\mathrm{do}(X := 1)$，得到 $p(Y_{X=1} \mid X = 2, Y = 6.5) = \delta(3.5)$，即 "$Y$ 本来会是 3.5"。这与干预分布 $p(Y \mid \mathrm{do}(X := 1)) = \mathcal{N}(3, 1)$ 不同，因为事实观察有助于确定背景状态（$U_X = 2, U_Y = 0.5$）。

SCM 的视角直观，也适合研究对函数类施加限制以实现归纳（第 2 节）。因此，后续章节将主要关注 SCM。

潜在结果(PO)。 潜在结果框架最初由 Neyman [98] 为随机化研究 [31] 提出，后来由 Rubin [124] 等推广，并扩展到观测情形。它在统计学和流行病学中很受欢迎，或许在后者的背景下最容易理解。这也反映在其术语上：在最常见的情形中，我们考虑一个二元治疗变量 T，其中 $T = 1$ 和 $T = 0$ 分别对应治疗组和对照组；我们关心它对结果变量 Y（通常是健康的某种度量）的因果效应。

与其统计学根源一致的一种解释，是将因果推断视为缺失数据问题。在 PO 框架中，对每个个体（或单位）i 及治疗值 t，存在一个 PO 或潜在响应，记为 $Y_i(t)$，刻画如果个体 i 接受治疗 t 会发生什么。潜在结果被视为确定性量：对给定个体 i，$Y_i(1)$ 和 $Y_i(0)$ 是固定的，实际结果 Y_i 中的所有随机性均来自治疗分配的随机性:

$$Y_i = TY_i(1) + (1 - T)Y_i(0). \tag{4.9}$$

为了决定患者 i 是否应接受治疗，我们需要推理两个潜在结果之差所刻画的个体化治疗效应（ITE）τ_i。

定义 4.12 (ITE)**.** 二元治疗下个体 i 的个体化治疗效应定义为

$$\tau_i = Y_i(1) - Y_i(0). \tag{4.10}$$

表 1: 作为缺失数据问题的因果推断：对于每个个体 i（各行），仅观察到与分配治疗 T_i 相对应的潜在结果 $Y_i(T_i)$；另一个潜在结果是反事实。因此，单位层面的因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 不可识别。

i	T_i	$Y_i(1)$	$Y_i(0)$	τ_i
1	1	7	?	?
2	0	?	8	?
3	1	3	?	?
4	1	6	?	?
5	0	?	4	?
6	0	?	1	?

“因果推断的基本问题” [51] 是，对于每个 i，我们只能观察到其中一个潜在结果。另一个未观测到的潜在结果成为反事实：

$$Y_i^{\text{cf}} = (1 - T)Y_i(1) + TY_i(0). \tag{4.11}$$

因此，在没有进一步假设的情况下，τ_i 永远不能从数据中测量或计算，即它不可识别，如表 1 所示。

式 (4.9) 和式 (4.11) 的形式隐含以下两个假设。

假设 4.13 (稳定单位处理值；SUTVA)**.** *一个单位的观测不应受其他单位治疗分配的具体方式影响 [23]。*

假设 4.14 (一致性)**.** *如果个体 i 接受治疗 t，那么观测结果为 $Y_i = Y_i(t)$，即治疗 t 的潜在结果。*

假设 4.13 通常被理解为：(i) 单位之间没有干扰；(ii) 每组（治疗组或对照组）只有一个治疗水平，从而潜在结果有良好的定义 [61]。它可能分别因以下情况而被违反：(i) 群体动力学，例如疫苗接种的群体免疫；(ii) 技术错误或组内剂量变化。然而，对于许多情形，例如受控研究，这可以是一个合理假设；此时我们可以将不同单位视为从一个总体中独立抽取的样本。

到目前为止，我们将给定单位的潜在结果视为确定性量。然而，大多数时候我们不可能完全刻画一个单位，例如在研究人类等复杂对象时。缺乏完整信息会引入不确定性，因此潜在结果经常被改为视作随机变量。这与 SCM 中确定性结构方程与外生噪声变量的结合相类似。[7]事实上，潜在结果与 SCM 之间存在等价关系 [104]：

$$Y_i(t) = Y \mid \text{do}(T := t) \quad \text{在 } U = u_i \text{ 的 SCM 中.}$$

因此，PO 框架中的一个个体对应于 SCM 中 U_j 的一个特定实例：给定 U 时结果是确定的，但由于我们没有观测到 u_i（也无法根据观测协变量刻画给定个体），反事实结果被视为随机变量。实践中，我们能够观察到的只是个体 i 的特征化描述 x_i，因此必须推理期望潜在结果 $\mathbb{E}[Y(1), Y(0) \mid x_i]$。

另一个常见假设是没有隐藏混杂因素。我们已经分别以 CGM 的因果 Markov 条件（定义 4.2）和 SCM 的因果充分性（假设 4.8）的形式遇到过它。在 PO 框架中，这表现为治疗与结果之间不存在隐藏混杂，并被称为（条件）可忽略性。

[7]当 SCM 中所有噪声变量都固定时，其他变量就被唯一确定；另一方面，在缺少完整背景知识时，它们是随机的。

假设 4.15 (条件可忽略性)**.** *给定治疗 $T \in \{0,1\}$、潜在结果 $Y(0), Y(1)$ 和观测协变量 X，我们有*

$$Y(0) \perp\!\!\!\perp T \mid X, \qquad Y(1) \perp\!\!\!\perp T \mid X. \tag{4.12}$$

PO 框架专门用于研究一个通常为二元的治疗变量对结果的（受混杂影响的）效应，主要用于因果推理，即估计个体和总体层面的因果效应（第 9 节）。在此背景下，不需要显式图表示有时被看作一个优点。与此同时，缺乏因果图且需要特殊的治疗和结果变量，使潜在结果框架不太适合因果发现，而其他框架在这一领域更为常用。

5 独立因果机制

现在回到联合分布 $p(X_1, \ldots, X_n)$ 的解缠结分解 (4.1)。只要 U_i 相互独立，这种依照因果图的分解总是可能的；但现在我们将考虑一个附加的独立性概念，它涉及式 (4.1) 中各因子彼此之间的关系。

考虑一个由气象站的海拔 A 和年平均气温 T 组成的数据集 [111]。变量 A 和 T 是相关的，我们相信这是因为海拔对温度有因果效应。假设我们有两个这样的数据集，分别来自奥地利和瑞士。两个联合分布可能相差很大，因为海拔的边缘分布 $p(A)$ 会不同。然而，条件分布 $p(T \mid A)$ 可能很相似，因为它们由海拔产生温度的物理机制决定。因此，因果分解 $p(A)p(T \mid A)$ 中有一个跨国家泛化的组成部分 $p(T \mid A)$，而纠缠的分解 $p(T)p(A \mid T)$ 则没有。略去一些细节，当我们考虑系统中的干预时，同样的论点也适用。为了使模型正确预测干预的效果，它需要能够稳健地从观测分布泛化到某些干预分布。

上述认识可表述如下 [111, 128]：

原理 5.1 (独立因果机制（ICM）)**.** *系统变量的因果生成过程由自主模块组成，这些模块之间既不提供信息，也不互相影响。在概率情形下，这意味着每个变量在给定其原因时的条件分布（即其机制）不向其他机制提供信息，也不影响其他机制。*

这一原理涵盖了几个对因果性重要的概念，包括因果变量可分别干预、子系统的模块化和自主性，以及不变性 [104, 111]。如果只有两个变量，它就归结为原因分布与由原因分布产生结果分布的机制之间的独立性。

将这一原理应用于因果分解 (4.1)，可知各因子应当在两种意义上独立：

- （影响）改变（或干预）一个机制 $p(X_i \mid \mathrm{PA}_i)$ 不会改变其他机制 $p(X_j \mid \mathrm{PA}_j)$ $(i \neq j)$；
- （信息）知道某些机制 $p(X_i \mid \mathrm{PA}_i)$ $(i \neq j)$ 不会提供关于机制 $p(X_j \mid \mathrm{PA}_j)$ 的信息。

我们将任何现实世界的分布看作因果机制的乘积。这样一个分布的变化（例如从一种情形或域转移到相关的另一种情形或域）总会由这些机制中至少一个的变化引起。与原理 5.1 一致，我们提出假说 [133]：

原理 5.2 (稀疏机制偏移（SMS）)**.** *分布的微小变化倾向于在因果 / 解缠结分解 (4.1) 中以稀疏或局部的方式呈现，即通常不应同时影响所有因子。*

相比之下，如果考虑非因果分解，例如式 (4.2)，当改变一个负责系统统计依赖关系的物理机制时，许多项将同时受到影响。因此，这样的分解可称为纠缠的。解缠结这一概念最近在机器学习中受到重视 [9, 50, 83, 147]，有时被宽泛地等同于统计独立性。不变、自主和独立机制的概念在因果研究历史上以各种形式出现，参见文献 [1, 104, 111, 133]。

机制依赖性的度量。 注意，两个机制 $p(X_i \mid \mathrm{PA}_i)$ 和 $p(X_j \mid \mathrm{PA}_j)$ 的依赖性不同于随机变量 X_i 和 X_j 的统计依赖。事实上，在因果图中，即使所有机制都独立，许多随机变量仍会是依赖的。考虑两个变量与结构赋值 $X := U$ 和 $Y := f(X)$，即原因 X 是噪声变量（其密度为 $p(x)$），结

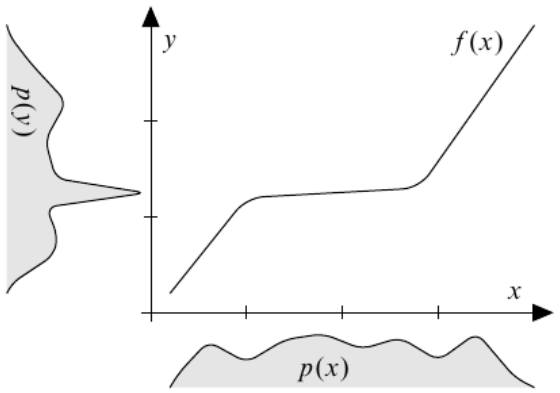


图 6: 如果 $p(x)$ 与 f 独立选取，那么 $p(y)$ 的峰值往往出现在 f 斜率较小的区域。因此，$p(y)$ 包含关于 f^{-1} 的信息（图源于文献 [111]）。

果 Y 是原因的确定性函数。进一步假定 X 和 Y 的值域均为 $[0, 1]$，且 f 严格单调递增。此时 ICM 原理归结为 $p(x)$ 与 f 的独立性。让我们将 $p(x)$ 和导数 f' 视为配备 Lebesgue 测度的概率空间 $[0, 1]$ 上的随机变量，并用二者的相关性作为机制依赖性的度量。可以证明，对于 $f \neq \mathrm{id}$，$p(x)$ 与 f' 的独立性蕴含 $p(y)$ 与 $(f^{-1})'$ 之间的依赖性（见图 6）。也可以使用其他度量，它们容许信息几何解释。直观地说，在 ICM 假设（原理 5.1）下，结果分布的“不规则性”变成以下两项之和：(i) 输入分布中已有的不规则性；(ii) 机制 f 引入的不规则性。也就是说，两个机制的不规则性相加，而不是（部分地）相互抵消。反方向（“反因果”方向）则并非如此（详情见文献 [68]）。对于高维线性情形和时间序列，还提出了其他依赖性度量 [12, 63, 67, 136]。

算法独立性。 到目前为止，我们讨论了因果结构与统计结构之间的联系。两者中更基本的是因果结构，因为它刻画了最初产生统计依赖关系的物理机制。当我们将未解释变量视为随机变量时，统计结构作为伴随现象随之产生。谈论机制中包含的（统计）信息有些别扭，因为一般情况下确定性函数既不产生也不销毁信息。这促使我们用 Kolmogorov 复杂度构造因果结构的算法模型 [65]。一个比特串的 Kolmogorov 复杂度（或算法信息）本质上是它在图灵机上最短压缩表示的长度，因而是其信息量的一种度量。机制的独立性可以定义为算法互信息为零：如果知道一个条件分布（的最短压缩表示）无助于获得另一个条件分布更短的压缩表示，则认为两者独立。

算法信息论为非统计图模型提供了自然框架。正如通过将未解释变量 U_i 随机化，可以从 SCM 得到统计 CGM 一样，我们通过将 U_i 设为比特串（在不同节点间联合独立），并将节点 X_i 视为固定图灵机以 PA_i 为输入运行程序 U_i 的输出，得到算法 CGM。类似于统计情形，可以定

义局部因果 Markov 条件、以 d-分离表述的全局条件，以及与式 (4.1) 类似的联合 Kolmogorov 复杂度分解，并证明 SCM 蕴含它们 [65]。这一方法表明，因果性并非在本质上与统计相绑定：因果性关乎支配信息流的机制，而信息流可以是统计的，也可以不是。

算法独立机制的假设对物理学有有趣的含义：它蕴含热力学第二定律（即时间之箭）。考虑一个过程：入射的有序光子束（原因）被一个物体（机制）散射。出射光束（结果）于是包含关于该物体的信息。在微观层面，时间演化是可逆的；然而，光子只在散射之后才包含关于物体的信息。Loschmidt 悖论 [86] 的基础是什么？

这种不对称性可以通过将 ICM 原理 5.1 应用于初始状态与系统动力学来解释：假定二者算法独立，即知道其中一个不能缩短对另一个的描述。于是可以证明，系统状态的 Kolmogorov 复杂度在时间演化下不减 [62]。如果我们将 Kolmogorov 复杂度看作熵的一种度量，这就意味着状态的熵只能保持不变或增加，相当于热力学第二定律。

注意，时间演化后的状态显然不独立于系统动力学：它恰恰是输入逆动力学后能够使我们回到原初（有序）状态的那个状态。

6 因果建模的层次

耦合微分方程是对物理现象建模的典型方式。它们使我们能够预测系统的未来行为、推理干预的效果，并通过适当的平均过程预测耦合时间演化所产生的统计依赖关系。它们还使我们能够洞察系统、解释它的运作，并尤其可以读出它的因果结构。

考虑一组耦合常微分方程

$$\frac{dx}{dt} = f(x), \qquad x \in \mathbb{R}^d, \tag{6.1}$$

其初值为 $x(t_0) = x_0$。我们假设它们正确描述了系统的物理机制。[8] Picard–Lindelöf 定理指出，如果 f 是 Lipschitz 的，那么至少在局部存在唯一解 $x(t)$。这特别意味着 x 的紧接着的未来由其过去的值所蕴含。

用无穷小微分 dt 和 $dx = x(t+dt) - x(t)$ 表示，式 (6.1) 写为

$$x(t+dt) = x(t) + dt \cdot f\big(x(t)\big). \tag{6.2}$$

由此我们可以确定向量 $x(t)$ 的哪些分量导致其他分量的未来 $x(t+dt)$，即确定因果结构。

与微分方程相比，从一组（与时间无关的）随机变量的联合分布导出的统计模型，对系统的描述相当表面。它利用了这样一个事实：只要实验条件不变，其中一些变量就可以用来预测其他变量。如果我们用某些类型的噪声驱动一个微分方程系统，或者对时间取平均，x 的各分量之间可能出现统计依赖关系，机器学习可以利用这些依赖关系。与微分方程模型不同，这样的模型不能让我们预测干预的效果；但其优势是通常能够从数据中学得。

因果建模位于这两个极端之间。它旨在提供理解并预测干预的效果。因果发现与学习则试图仅使用较弱的假设，以数据驱动的方式获得这类模型（见表 2，取自文献 [111, 133]）。

我们或许会天真地以为因果性总是与时间有关，但现有的多数因果模型并不考虑时间，也不需要考虑时间。例如，回到海拔与温度的例子，背后存在一个动力学物理过程，使较高的地方

[8] 换言之，它们并非仅仅在现象学层面描述系统的时间演化，却没有捕捉潜在机制，例如由于未观测到的混杂因素，或由于不保留因果结构的某种粗粒化 [123, 133]。

表 2: 模型的一种简单分类。最详细的模型（顶部）是机制或物理模型，通常以微分方程表示。另一端（底部）是纯统计模型；它可以从数据中学得，并可用于预测，但除了对伴随现象之间的关联建模之外，往往几乎不能提供其他洞见。因果模型可视为位于二者之间的描述：它们抽象掉物理现实性的细节，同时保留回答某些干预或反事实问题的能力。

模型	独立同分布条件下预测	分布偏移 / 干预下预测	回答反事实问题	获得物理洞见	从数据学习
机制 / 物理	是	是	是	是	?
结构因果	是	是	是	?	?
因果图	是	是	否	?	?
统计	是	否	否	否	是

趋于更冷。在有关粒子的微观运动方程层次上，存在一个时间性的因果结构。然而，当我们讨论海拔与温度之间的依赖或因果关系时，不必担心这一时间结构的细节：我们得到一个没有时间的数据集，并且可以推理如果对温度或海拔进行干预，这个数据集会是什么样子。

已有一些研究试图在这些不同描述层次之间建立桥梁。可以推导出这样的 SCM：它们描述一个处于平衡态、受到绝热扰动的耦合系统的干预行为 [96]；这一结果也推广到了振荡系统 [122]。在这一工作中，SCM 是底层微分方程系统的高层抽象。只有能够定义适当的高层变量时，才能推导出它 [123]；在实践中，这很可能是例外而非常态。

7 因果发现

有时，领域知识或事件的时间顺序可以帮助约束变量之间的因果关系。例如，我们可能知道年龄或性别等某些属性不是由其他变量引起的；治疗影响健康结果；而事件不会对其过去产生因果影响。当这种领域知识不可得或不完整时，我们需要进行因果发现：推断哪些变量对哪些其他变量有因果影响，即从数据中学习因果结构（例如 DAG）。由于实验往往难以实施且成本高昂，而观测数据（即被动收集的数据）却很丰富，因此从观测数据中进行因果发现尤其受到关注。

正如第 3 节讨论共同原因原理 3.2 时所说，只有两个变量的情况已经很困难，因为多个不同的因果结构可以解释同一种依赖关系。因此，人们可能会问，可观测变量更多时，情况是否完全没有希望。令人惊讶的是，并非如此：问题（在某种意义上）变得更容易，因为因果结构蕴含非平凡的条件独立性质 [25, 35, 145]。在返回双变量情况之前，我们先回顾两种处理多变量情形的经典方法。

基于约束的方法。 基于约束的因果发现方法检验能够从数据中推断出哪些（条件）独立性，然后尝试找到一个蕴含这些独立性的图。因此，这类方法也称为基于独立性的方法。这样的过程需要一种将数据分布 p 的性质与底层因果图 G 的性质联系起来的方法。这一联系称为忠实性假设。

假设 7.1 (忠实性)**.** *p 满足的（条件）独立性只有因果 Markov 条件（定义 4.2）所蕴含的那些。*

忠实性可视为因果 Markov 条件的逆命题。两者共同建立了 G 中图分离与 p 中条件独立性

之间的一一对应。因果 Markov 条件按构造成立，而忠实性是一项可能被违反的假设。违反忠实性的经典例子是沿不同路径的因果效应相互抵消。

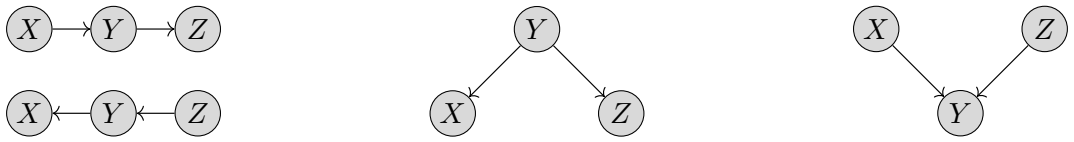
例 7.2 (违反忠实性)**.** *考虑例 4.6 的 SCM，令*

$$X_1 := U_1, \qquad X_2 := \alpha X_1 + U_2, \qquad X_3 := \beta X_1 + \gamma X_2 + U_3,$$

其中 $U_1, U_2, U_3 \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,1)$*。代入可得* $X_3 = (\beta + \alpha\gamma)X_1 + \gamma U_2 + U_3$*。因此，只要* $\beta + \alpha\gamma = 0$*，就有* $X_3 \perp\!\!\!\perp X_1$*，尽管这一独立性不是诱导因果图 G 上的因果 Markov 条件所蕴含的，见图 5。此处，如果* X_1 *对* X_3 *的直接效应* β *与经由* X_2 *的间接效应* $\alpha\gamma$ *相互抵消，就违反了忠实性。*

除了依赖忠实性之外，基于约束的方法的一个根本限制是：许多不同的 DAG 可以编码相同的 d-分离 / 独立关系。这称为 Markov 等价，图 7 给出了示意。

定义 7.3 (Markov 等价)**.** *如果两个 DAG 编码相同的 d-分离陈述，就称它们 Markov 等价。编码相同 d-分离关系的所有 DAG 的集合称为一个 Markov 等价类。*



(a) 链 (b) 分叉 (c) 碰撞点

图 7: 用常见图结构说明 Markov 等价。(a) 中的链与 (b) 中的分叉均蕴含 $X \perp\!\!\!\perp Z \mid Y$（而无其他独立性），因而构成一个 Markov 等价类，仅通过条件独立性检验无法将它们区分。(c) 中的碰撞点或 v-结构蕴含 $X \perp\!\!\!\perp Z$（但 $X \not\perp\!\!\!\perp Z \mid Y$），并构成其自身的 Markov 等价类，因此可以从观测数据唯一识别。由此，v-结构有助于因果发现。可以证明，两个图 Markov 等价，当且仅当它们具有相同的骨架和 v-结构。

基于约束的算法通常首先构造一个无向图或骨架，以刻画通过检验发现的（条件）独立性，然后使用 Meek 定向规则 [90] 尽可能为更多边定向。第一步承担了大部分计算量，人们设计了多种算法来高效求解。

最简单的过程由 IC [109] 和 SGS [144] 算法实现。对于每对变量 (X, Y)，它们搜索其余变量的所有子集 W，检查是否有 $X \perp\!\!\!\perp Y \mid W$。如果找不到这样的集合 W，就用一条边连接 X 和 Y。由于子集数量众多，这种方法可能很慢，因此 PC 算法 [144] 使用更高效的搜索过程：它从完全图开始，然后按子集大小递增的顺序，依次只检验 X 或 Y 的邻居的子集；找到分离子集时便移除相应边。对于因果不充分的系统，即存在隐藏混杂因素时，这种邻居搜索不再保证给出正确结果。FCI（快速因果推断）算法 [144] 针对这一情形，输出一个部分定向的因果图。

基于约束的方法除了受限于只能恢复一个 Markov 等价类，还可能遭遇统计问题。实践中的数据集是有限的，而条件独立性检验是出了名的困难，尤其是在条件集合连续且多维时。因此，尽管原则上因果 Markov 条件所蕴含的条件独立性不依赖于 SCM 中函数的复杂程度而成立，但对于有限数据集，如果没有额外假设，条件独立性检验是困难的 [135]。近年来（条件）独立性检验的进展大量依赖核函数类在再生核 Hilbert 空间中表示概率分布，见第 2 节。

基于评分的方法。 基于评分的因果发现方法对候选图集合（通常是所有 DAG 的集合）中的每个图 G 赋予一个分数。分数 S 应当反映 G 对观测数据 $D = \{x_1, \dots, x_m\}$ 的解释程度，我们选择使这一分数最大的图 $\hat{G}$:

$$\hat{G} = \arg\max_{G} S(G \mid D).$$

人们提出了各种评分函数，但多数方法假定一个根据 G 分解、由 $\theta \in \Theta$ 参数化的参数模型。两种常见选择是用于离散数据的多项分布模型 [22] 和用于连续数据的线性高斯模型 [34]。例如，以 BIC [134] 为评分的惩罚最大似然方法得到

$$S_{\mathrm{bic}}(G \mid D) = \log p(D \mid G, \hat{\theta}_{\mathrm{mle}}) - \frac{k}{2} \log m, \tag{7.1}$$

其中 k 是参数个数，$\hat{\theta}_{\mathrm{mle}}$ 是图 G 中 θ 对数据 D 的最大似然估计。注意，k 通常随 G 的边数增加，所以式 (7.1) 的第二项惩罚那些没有带来实质改进的复杂图。

另一种评分函数是贝叶斯因果发现方法中的边缘似然或证据，它需要指定图和参数上的先验分布 $p(G, \theta) = p(G)p(\theta \mid G)$。此时 G 的评分为

$$S_{\mathrm{bayes}}(G \mid D) = p(D \mid G) = \int_{\Theta} p(D \mid G, \theta) p(\theta \mid G)\, d\theta. \tag{7.2}$$

这一积分一般难以计算，但在某些温和的附加假设下，可以对 Dirichlet–多项分布等模型精确计算 [47, 48]。

基于评分方法的一大缺点是搜索空间的组合规模。n 个随机变量上的 DAG 数目以超指数速度增长，并可以递归计算（以考虑无环约束）[119]。例如，当节点数 $n = 5$ 和 $n = 10$ 时，DAG 数分别为 29281 和 4175098976430598143。寻找评分最高的 DAG 是 NP-hard 问题 [20]。为了克服这一问题，可以使用贪婪搜索技术，例如优化 BIC 的贪婪等价搜索（GES） [21]。

近年来又出现了另一类方法，它们基于对 SCM 赋值采用特定函数形式的假设。这些方法源于对因果方向推断问题的研究，下面将作讨论。

因果方向推断。 当只有两个变量时，涉及三个部分的条件独立性概念退化，因果 Markov 条件（定义 4.2）因而没有非平凡的推论。然而，我们在第 5 节看到，假设机制独立（原理 5.1）能让我们找到原因与结果之间的不对称性，从而解决此前被认为无法解决的因果方向推断问题 [68]。事实表明，也可以通过对函数类作额外假设来处理这一问题，因为不仅图拓扑会在观测分布中留下痕迹，SCM 中的函数 f_i 也会留下痕迹。这类假设在机器学习中很典型：众所周知，如果不对函数类作假设，就不可能实现有限样本泛化；人们也十分关注函数类的性质（例如先验或容量度量），如第 2 节所述。

让我们直观说明，为何关于 SCM 中函数的假设有助于从数据中学习这些函数。考虑一个只有两个可观测变量 $X \to Y$ 的玩具 SCM。此时，结构方程 (4.5) 变为

$$X := U, \qquad\qquad Y := f(X, V), \tag{7.3}$$

其中噪声满足 $U \perp\!\!\!\perp V$。现在将 V 看作随机选择变量，从一组函数 $\mathcal{F} = \{f_v(x) \equiv f(x, v) \mid v \in \mathrm{supp}(V)\}$ 中选择。如果 $f(x, v)$ 对 v 的依赖是不光滑的，那么鉴于 V 未被观测且它在可能任意

不同的 f_v 之间随机切换，应当很难从有限数据集中获取关于 SCM 的信息。[9] 这促使我们限制 f 对 V 的依赖复杂度。一个自然的限制是假设加性噪声模型

$$X := U, \qquad Y := f(X) + V. \tag{7.4}$$

如果式 (7.3) 中的 $f(x, v)$ 光滑依赖于 V，并且 V 相对集中，那么可以通过局部 Taylor 展开来说明这一假设的动机。这类假设大幅减小了函数类的有效规模——没有它们，后者可能以 V 支集基数的指数速度增长。

对函数类施加限制可以打破双变量情形下原因与结果之间的对称性：可以证明，给定一个由加性噪声模型生成的 X, Y 上的分布，不能在反方向（即交换 X 和 Y 的角色）拟合加性噪声模型 [6, 53, 76, 95, 113]。这一结论依赖某些一般性假设，其中值得注意的例外包括 U, V 为高斯变量且 f 为线性的情况。它推广了文献 [139] 对线性函数的结果，也可以进一步推广至非线性重缩放 [164]、环 [94]、混杂因素 [64] 和多变量因果发现 [112]。目前已有一系列方法可以以优于随机猜测的水平检测因果方向 [97]。

因此，我们已经收集到一些证据，表明机器学习中的思想有助于解决以前被认为困难的因果问题。然而，同样令人感兴趣的是反方向：因果性能否帮助我们改进机器学习？

基于非平稳性的方法。 我们最后介绍的一类因果发现方法基于非平稳性和不变性的思想 [128]。这些方法不适用于在独立同分布情形下收集的纯观测数据；相反，它们旨在利用从不同环境中收集的数据的异质性。主要思想如下：由于按照 ICM 原理 5.1，因果系统是模块化的，改变一个独立机制应当使其他组成部分或因果条件分布保持不变（SMS 原理 5.2）。因此，按照底层因果结构对联合分布进行正确分解，应当能够用一个或少数几个机制的局部变化解释异质性，而其他机制保持不变。

最早使用这一思想的工作之一 [150] 分析了给定一组机制变化产生的数据时，哪些因果结构可以区分。近期工作 [55] 还试图学习机制变化的低维表征。其他研究 [110, 120] 提出了寻找给定目标变量直接原因的方法。利用一个同样依赖非平稳性的非线性独立成分分析（ICA）可识别性近期结果 [59]，人们提出了学习一般非线性 SCM 的方法 [93]。这里的思想是训练一个分类器，区分某个非平稳性变量（例如时间戳或环境指示变量）的真实值和该变量经打乱后的值。

8 对机器学习的启示

半监督学习。 假设底层因果图为 $X \to Y$，而我们试图学习映射 $X \to Y$。这种情形的因果分解 (4.1) 为

$$p(X, Y) = p(X)p(Y \mid X). \tag{8.1}$$

ICM 原理 5.1 认为，联合分布的因果分解中的模块既不向彼此提供信息，也不相互影响。这特别意味着，$p(X)$ 不应包含关于 $p(Y \mid X)$ 的信息，而这又蕴含半监督学习 [17] 应当徒劳无功，因为它试图利用关于 $p(X)$ 的额外信息（来自无标签数据）来改进对 $p(Y \mid X = x)$ 的估计。反方

[9] 假设 X 和 Y 都是二元变量，U, V 是均匀 Bernoulli 变量，而后者从 $\mathcal{F} = \{\mathrm{id}, \mathrm{not}\}$（即恒等和取反）中选择。在这种情况下，所产生的 Y 的分布是均匀的，且独立于 X，即使存在 $X \to Y$。我们将无法从数据中辨别出 $X \to Y$。（这也会违反忠实性假设 7.1。）

向又如何？这种情况下是否有希望进行半监督学习？事实表明，答案是肯定的，这是由于使用 ICM 原理 5.1 进行因果方向推断的研究 [24]。该研究引入了输入与给定输入的输出条件分布之间的依赖性度量，并表明，如果这一依赖在因果方向上为零，那么在反方向上严格为正。因此，原因与机制在因果方向上的独立性意味着，在反向（即反因果学习）中，输入变量的分布应当包含关于给定输入的输出条件分布的信息，而后者正是机器学习通常关心的量。这恰恰是半监督学习试图利用无标签输入改进给定输入的输出估计时所需要的信息。

这表明，对于因果学习问题，半监督学习应当是不可能的；但在其他情形下，尤其是反因果情形下，它是可行的。对已发表半监督学习基准研究的一项荟萃分析支持了这一预测 [128]，自然语言处理也有类似结果 [69]。这些发现引人关注，因为它们提供了对学习问题物理性质的认识，从而超越了机器学习研究通常提供的方法和应用。

后续进展包括进一步的理论分析 [66, 111] 以及一种条件半监督学习形式 [156]。将半监督学习视为利用边缘分布 $p(x)$ 与非因果条件分布 $p(y \mid x)$ 之间的依赖关系，这一观点与用于论证半监督学习合理性的常见假设一致 [17, 125]。

不变性与稳健性。 我们已经讨论了独立同分布假设的不足：它在实践中很少精确成立；而真实世界中的智能体需要能够在不同的相关问题之间泛化，而不只是局限于单个独立同分布情形。这一概念被称为分布外（o.o.d.）泛化，近年来受到了广泛关注 [133]。尽管迄今多数研究是经验性的，但我们希望获得能够推广式 (2.4) 的统计界，包括度量训练分布与测试分布之间距离的额外量，并纳入有意义的假设 [137]。这些假设是必要的 [8]，可以是因果性的，也可以与不变性质有关。

近年来出现的“对抗脆弱性”现象 [148] 表明，通过向图像添加适当选择的噪声（人类无法察觉）而产生的、对独立同分布假设极其微小且有针对性的违反，可能导致危险的错误，例如混淆交通标志。这些例子令人信服，因为它们展示了人工系统所具有、而人类感知不具有的不稳健性。因此，我们自身的感知表现出不容易从单个训练集中学到的不变性或稳健性。

与域偏移有关的早期因果研究 [128] 考察了从多个共享函数机制但噪声分布不同的因果数据集中学习的问题。更一般地，给定多个分布（的数据），我们可以尝试识别稳健的组成部分，并寻找将它们在不同问题间迁移的方法 [4, 36, 54, 163, 166]。根据 ICM 原理 5.1，条件分布或函数的不变性（在简单情形下也称为协变量偏移）应当仅在因果方向上成立，这与上述半监督学习的不可能性形成相反的情况。

在文献 [110, 128] 的工作基础上，用于预测的不变性思想也已被用于监督学习 [3, 87, 120]。特别地，“不变风险最小化”（IRM）被提出作为 ERM 的替代方案，参见式 (2.3)。

9 因果推理

与旨在揭示一组变量背后因果结构的因果发现（第 7 节）不同，因果推理从已知（或假定）的因果图出发，回答感兴趣的因果查询。因果发现常常寻找定性关系，而因果推理通常旨在量化这些关系。这需要两个步骤：(i) 识别查询，即为其推导出只涉及观测量的估计目标；(ii) 利用数据估计该目标。感兴趣的量往往可以描述为治疗效应，即两个干预之间的对比。

定义 9.1 (治疗效应)**.** *以（部分）特征 x 为条件的条件平均治疗效应（CATE）定义为*

$$\tau(x) := \mathbb{E}[Y \mid x, \mathrm{do}(T=1)] - \mathbb{E}[Y \mid x, \mathrm{do}(T=0)] = \mathbb{E}[Y(1) - Y(0) \mid x]. \tag{9.1}$$

平均治疗效应（ATE）定义为 CATE 的总体平均：

$$\tau := \mathbb{E}[\tau(X)] = \mathbb{E}[Y \mid \mathrm{do}(T=1)] - \mathbb{E}[Y \mid \mathrm{do}(T=0)] = \mathbb{E}[Y(1) - Y(0)]. \tag{9.2}$$

虽然 ITE（定义 4.12）和 CATE (9.1) 有时可以互换使用，但概念上存在区别：ITE 是两个潜在结果之差，因而与个体绑定；CATE 适用于子总体，例如四十多岁女性的 CATE。由于 ITE 在根本上无法观察，人们常借助适当的额外假设，用以个体特征 x_i 为条件的 CATE 估计它。

由定义 9.1 可见，我们希望估计的治疗效应涉及干预表达式。然而，我们通常只能获得观测数据。因此，因果推理可以表述为使用观测数据和因果模型回答干预查询。这涉及处理已观测和未观测的混杂因素。

在讨论如何识别和估计因果效应之前，我们使用一个众所周知的统计现象来说明为什么需要因果假设。

Simpson 悖论与 Covid-19。 Simpson 悖论指这样一种现象：跨子总体聚合数据可能得到与分别考虑各子总体相反的趋势，因而导致相反结论 [142]。在 Covid-19 大流行期间，比较不同国家和年龄组的病例病死率（CFR，即确诊 Covid-19 病例中死亡的比例）时，我们观察到一个教科书式的例子，如图 8 所示 [154]：对于所有年龄组，意大利的 CFR 均低于中国，但意大利的总体 CFR 更高。

如何解释这种模式？两国的病例人口结构（见图 8 右图）相当不同，即国家与年龄之间存在统计关联。特别是，意大利记录的病例中老年患者占比大得多，而老年患者通常面临更高的 Covid-19 死亡风险（见图 8 左图）。尽管这在统计意义上提供了一致的解释，这一现象仍可能显得令人困惑，因为它违背了我们的因果直觉。人们似乎自然地将条件概率外推并理解为因果效应，这可能导致不一致的结论，让人疑惑：为何这种疾病在意大利对年轻人和老年人都较不致命，但对总体人群却更致命？正因如此，图 8 中（条件）概率的反转被视为并称为“悖论” [49, 105]。如果我们将国家视为治疗，关心它对死亡的因果效应，那么就需要因果假设（例如因果图的形式）来决定如何处理与治疗统计相关的协变量，例如是否按年龄分层（即调整年龄）。这也解释了为什么随机对照试验（RCT） [31] 是因果推理的金标准：随机分配打破治疗变量与其他协变量之间任何潜在的联系，从而消除潜在的偏倚问题。然而，RCT 成本高昂，有时实施起来不符合伦理，因此因果推理往往只能依赖观测数据。[10]

[10] 关于更一般的数据融合形式，以及实验发现跨不同总体的可迁移性，参见文献 [5, 106]。

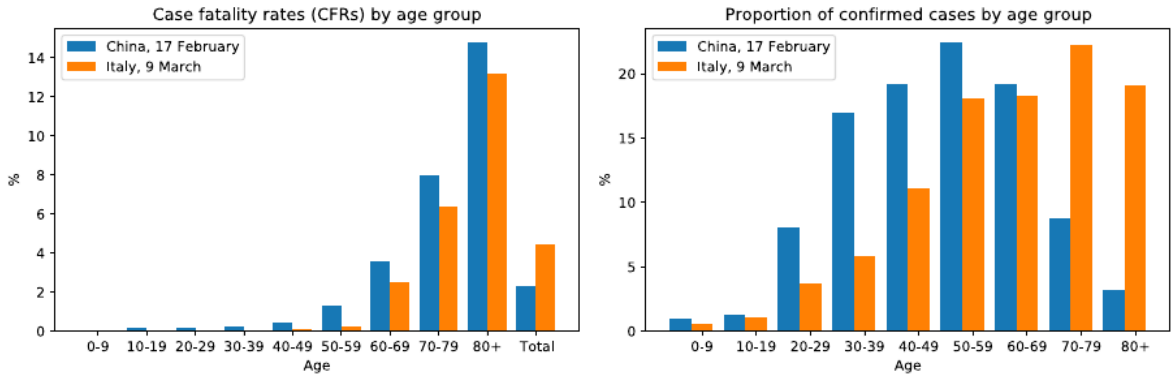


图 8: （左）意大利和中国按年龄分组及总体（Total）的 Covid-19 病例病死率（CFR），包括截至 2020 年初报告时的所有确诊病例和死亡病例（见图例）：所有年龄组中意大利的 CFR 均低于中国，但意大利总体 CFR 更高，这是 Simpson 悖论的一个例子。（右）两国的病例人口结构不同：意大利多数病例发生在较年长人群（图源于文献 [154]）。图例蓝色为中国（2 月 17 日）、橙色为意大利（3 月 9 日）；左图标题为各年龄组的病例病死率，右图为各年龄组的确诊病例占比；横轴为年龄组，纵轴为百分比。

我们首先考虑没有隐藏混杂因素且具有重叠性的最简单情形。我们从总体层面治疗效应的识别开始，然后讨论从数据中估计这些效应的不同技术。

识别。 在不存在未测量变量（即没有隐藏混杂）的情况下，只要知道因果图，就可以通过对协变量进行调整来计算因果效应。Robins [117] 提出了一种适用于任何给定图的原则性方法，称为 *g*-计算公式（其中 g 表示 general，即一般）。它也称为截断分解 [104] 或操纵定理 [144]。它依赖因果机制的独立性（原理 5.1），即对一个变量进行干预会使式 (4.1) 中其他因果条件分布保持不变：

$$p\big(X_1,\dots,X_n \mid \mathrm{do}(X_i := x_i)\big) = \delta(X_i = x_i)\prod_{j\neq i} p(X_j \mid \mathrm{PA}_j). \tag{9.3}$$

由式 (9.3) 可通过边缘化获得感兴趣的干预分布。这与图手术的思想有关（见图 5），并导出一组三条用于处理干预分布的推断规则，称为 *do*-演算 [104]；已有证明表明它们对于识别因果效应是完备的 [56, 140]。注意，即使没有清楚地直接同时影响治疗和结果的混杂因素，仍然可能需

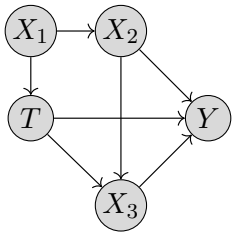


图 9: 使用三个已观测协变量 X_1, X_2, X_3 估计治疗效应：这里 $T \to Y$ 的有效调整集（见命题 9.3）是 $\{X_1\}$、$\{X_2\}$ 和 $\{X_1, X_2\}$。纳入 X_3 会打开非有向路径 $T \to X_3 \leftarrow X_2 \to Y$，并且 X_3 位于有向路径 $T \to X_3 \to Y$ 上，两者都可能引入偏倚。

要协变量调整，如图 9 的例子所示。

例 9.2. 将 g-计算公式 (9.3) 应用于图 9，得到

$$p(y \mid \mathrm{do}(t)) = \sum_{x_1} p(x_1) \sum_{x_2} p(x_2 \mid x_1) \sum_{x_3} p(x_3 \mid t, x_2) p(y \mid t, x_2, x_3) \tag{9.4}$$

$$= \sum_{x_1} p(x_1) \sum_{x_2} p(x_2 \mid x_1) p(y \mid t, x_2) = \sum_{x_2} p(x_2) p(y \mid t, x_2) \tag{9.5}$$

$$\overset{(a)}{=} \sum_{x_1, x_2} p(x_1, x_2) p(y \mid t, x_1, x_2) \overset{(b)}{=} \sum_{x_1} p(x_1) p(y \mid t, x_1), \tag{9.6}$$

最后一行使用了该图蕴含的条件独立性：(a) $Y \perp\!\!\!\perp X_1 \mid \{T, X_2\}$；$(b)$ $X_2 \perp\!\!\!\perp T \mid X_1$。

注意，式 (9.5) 的右侧与式 (9.6) 的两侧都具有形式

$$p(y \mid \mathrm{do}(t)) = \sum_{z} p(z) p(y \mid t, z). \tag{9.7}$$

在这种情况下，我们称 Z 是 T 对 Y 效应的有效调整集。此处 $\{X_1\}$、$\{X_2\}$、$\{X_1, X_2\}$ 均为有效调整集，但可以证明，例如 $\{X_1, X_3\}$ 不是（见图 9）。当协变量很多时，计算 g-公式可能很繁琐，因此即使不存在未观测混杂因素，判断哪些子集构成有效调整集的图准则在实践中也很有用。

命题 9.3 ([141])**.** 在因果充分性下，集合 Z 是单变量治疗 T 对结果 Y 的因果效应的有效调整集（在式 (9.7) 的意义下），当且仅当以下两个条件成立：(i) Z 不包含从 T 到 Y 的有向路径上任何节点的后代（T 的那些不位于从 T 到 Y 的有向路径上的后代除外）；(ii) Z 阻断从 T 到 Y 的所有非有向路径。

这里，如果一条路径上的所有有向边都指向相同方向，则称其为有向路径，否则称为非有向路径。如果路径包含由以下三种方式之一连接的连续三个节点，则称其被顶点集 Z 阻断：$A \to B \to C$ 且 $B \in Z$；$A \leftarrow B \to C$ 且 $B \in Z$；或者 $A \to B \leftarrow C$，其中 B 及其任何后代均不在 Z 中。

命题 9.3 蕴含两种众所周知的调整集：父节点调整，其中 $Z = \mathrm{Pa}_T$；以及后门准则，其中 Z 不含 T 的后代，且阻断从 T 到 Y 的所有“后门路径”（$T \leftarrow \cdots \to Y$）。注意，命题 9.3 只适用于单变量治疗（即对单一变量干预）。对于涉及多个变量的治疗 T，可以用适当因果路径给出稍复杂一些的命题版本，详情参见文献 [102, 108]。

让我们简要回到前面 Simpson 悖论与 Covid-19 的例子。考虑该情形的一个合理因果图 [154]，我们发现年龄 A 在国家 C 对死亡 F 的因果效应中充当中介：$C \to A \to F$（很可能还存在直接效应 $C \to F$，它可能由其他未观测变量中介）。如果关心 C 对 F 的（总体）因果效应，即国家对死亡的整体影响，按照命题 9.3 不应将 A 纳入调整，而且在因果充分性条件下，总体 CFR 可以作因果解释。[11]另一方面，对于肾结石治疗中 Simpson 悖论的另一个经典例子 [18]，结石大小充当混杂因素，因此需要对其调整才能得到可靠的因果结论。

有效协变量调整和 g-公式告诉我们，没有隐藏混杂因素时如何从观测分布计算干预。然而，为了实际从数据中识别因果效应，还需要能够估计式 (9.7) 所涉及的量。如果某个总体子群从不（或总是）接受某种治疗，就会出现问题。因此，我们还需要接受每种可能治疗的概率非零的假设，称为重叠性或共同支撑。

[11]中介分析 [103] 提供区分并量化直接与间接效应的工具；图 8 中各年龄组的 CFR 对应受控直接效应 [154]。

假设 9.4 (重叠性 / 共同治疗支撑)**.** 对于任意治疗 t 和任意特征配置 x，有 $0 < p(T = t \mid X = x) < 1$。

重叠性与可忽略性（即没有隐藏混杂因素，见假设 4.15）的组合也称为强可忽略性，是识别 ATE 和 CATE 的充分条件：不存在隐藏混杂因素保证存在有效调整集 $Z \subseteq X$，使得 $p(Y \mid \mathrm{do}(T = t), Z) = p(Y \mid T = t, Z)$；重叠性保证我们确实能够对所有以非零概率出现的 z 估计后者。[12]

回归调整。 确定有效调整集后（使用命题 9.3），回归调整通过观测样本 $\{(y_i, t_i, z_i)\}_{i=1}^m$ 拟合回归函数 $\hat{f}$ 来估计 $\mathbb{E}[Y \mid Z = z, T = t] = f(z, t)$。随后可以用 $\hat{f}$ 填补反事实结果 $\hat{y}_i^{\mathrm{cf}} = \hat{f}(z_i, 1 - t_i)$，以估计 CATE。ATE 则由总体平均给出，可估计为

$$\hat{\tau}_{\text{regression-adj.}} = \frac{1}{m_1} \sum_{i:t_i=1} \big(y_i - \hat{f}(z_i, 0)\big) + \frac{1}{m_0} \sum_{i:t_i=0} \big(\hat{f}(z_i, 1) - y_i\big), \tag{9.8}$$

其中 m_1, m_0 分别是治疗组和对照组的观测数。[13]注意它与无需调整的 RCT 估计量的区别：

$$\hat{\tau}_{\mathrm{RCT}} = \frac{1}{m_1} \sum_{i:t_i=1} y_i - \frac{1}{m_0} \sum_{i:t_i=0} y_i. \tag{9.9}$$

匹配与加权方法。 回归调整通过 CATE 间接估计 ATE，而匹配和加权方法旨在直接估计 ATE。其总体思路是尽可能模拟 RCT 的条件。

匹配方法根据特征相似性将总体分成子群。可以在个体层面进行（称为一对一或最近邻匹配）：为每个个体 i 从相反治疗组中匹配最相似的个体 $j(i)$（即 $t_i \neq t_{j(i)}$）。随后将结果之差 $y_i - y_{j(i)}$ 视为 ATE 的一个样本，并取平均作为估计：

$$\hat{\tau}_{\text{NN-matching}} = \frac{1}{m_1} \sum_{i:t_i=1} (y_i - y_{j(i)}) + \frac{1}{m_0} \sum_{i:t_i=0} (y_{j(i)} - y_i). \tag{9.10}$$

另一种做法是将总体分为特征相似的较大子群（称为层）。然后将每一层视为独立的 RCT。如果共有 K 个层，分别包含 $m_1, \ldots, m_K$ 个观测，则分层 ATE 估计量为

$$\hat{\tau}_{\text{stratified}} = \frac{\sum_{k=1}^K m_k \hat{\tau}_{\mathrm{RCT}}^{(k)}}{\sum_{k=1}^K m_k}, \tag{9.11}$$

其中 $\hat{\tau}_{\mathrm{RCT}}^{(k)}$ 是将式 (9.9) 应用于第 k 层观测得到的估计量。

另一方面，加权方法旨在通过重新加权每个观测，使总体更能代表 RCT，从而抵消混杂偏倚。这意味着对代表性不足的治疗组增大权重，对代表性过高的治疗组减小权重。一个例子是逆概率加权（IPW）估计量：

$$\hat{\tau}_{\mathrm{IPW}} = \frac{1}{m_1} \sum_{i:t_i=1} \frac{y_i}{p(T = 1 \mid Z = z_i)} - \frac{1}{m_0} \sum_{i:t_i=0} \frac{y_i}{p(T = 0 \mid Z = z_i)}. \tag{9.12}$$

译注： 式 (9.12) 的分组归一化也需核查。例如在等概率随机治疗且所有个体 $Y(1) = 1$、$Y(0) = 0$ 时，原式给出 2 而非总体平均效应 1。原式在此照录，不作静默更改。

治疗概率 $p(T = 1 \mid Z)$ 也称为倾向得分。虽然从理论上说 Z 应当是有效调整集，但实践者有时会使用所有协变量来构造倾向得分。

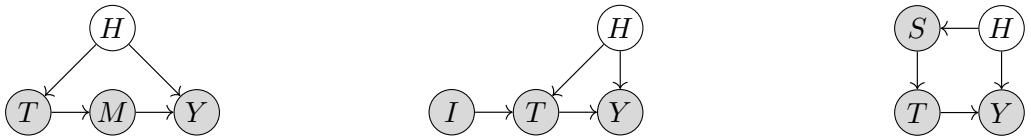
[12]因此，重叠性假设可以放宽为对至少一个有效调整集成立。

[13]译注：式 (9.8) 与下文式 (9.10) 均照原文保留，但其两组分别取平均后直接相加的归一化需要核查。例如所有个体均有 $Y(1) = 1$、$Y(0) = 0$，两组非空且使用真实结果填补反事实时，两式均给出 2 而非 1。

倾向得分方法。 为了克服维数灾难，并在高维、小数据情形下提高统计效率，倾向得分可能是一种有用工具，因为倾向得分 $s(z) := p(T = 1 \mid Z = z)$ 使协变量与治疗条件独立，即 $T \perp\!\!\!\perp Z \mid s(z)$ [121]。因此，可以使用标量倾向得分，而不是对大量特征集合进行调整或在高维空间中进行匹配。将这一思想应用于上述方法，就得到倾向得分调整和倾向得分匹配。对于后者，倾向得分之差作为实例之间的相似性，用于寻找最近邻或定义层。

倾向得分虽然在某方面简化了问题，但它需要从数据中估计，这带来了额外误差。标准方法是通过逻辑回归估计 $s(z)$，但也可以使用更复杂的方法。然而，要得到无偏结果，倾向得分方法仍依赖于已经确定有效调整集 Z。因此，若不检查其是否构成有效调整集就使用所有协变量估计 s，可能导致错误结果。

接下来考虑存在未观测混杂因素的因果推理。尽管在一般情形下无法识别因果效应，我们将讨论两种仍可估计 ATE 的特殊情况，如图 10(a)、(b) 所示。



(a) 前门 (b) 工具变量 (c) RDD

图 10: 强可忽略性假设（无隐藏混杂或重叠性）不成立时，允许估计治疗 T 对结果 Y 因果效应的特殊情形概览。(a) 借助观测中介变量 M 处理隐藏混杂因素 H；(b) 依赖与 H 独立的工具变量（IV）；(c) 在回归不连续设计（RDD）中，治疗分配是某个观测决策得分 S 的阈值函数，因此治疗组之间不存在重叠。

前门调整。 第一种情形中，即使隐藏变量 H 混杂治疗与结果之间的效应，识别仍然可能，称为前门调整。相应因果图见图 10(a)。前门调整依赖一个已观测变量 M 的存在，它阻断从 T 到 Y 的所有有向路径，使 T 只通过 M 对 Y 产生因果影响。因此 M 也称为中介变量。另一个重要假设是，隐藏混杂因素除通过治疗 T 外不影响中介变量，即 $M \perp\!\!\!\perp H \mid T$。在此情况下，并假设对所有 t, m 有 $p(t, m) > 0$，T 对 Y 的因果效应是可识别的，结果如下。

命题 9.5 (前门调整)**.** *对于图 10(a) 的因果图，有*

$$p(y \mid \mathrm{do}(t)) = \sum_m p(m \mid t) \sum_{t'} p(t') p(y \mid m, t'). \tag{9.13}$$

我们给出推导概要，使用 *do*-演算规则的证明参见文献 [104]。由于 M 中介 T 对 Y 的因果效应，有

$$p(y \mid \mathrm{do}(t)) = \sum_m p(m \mid \mathrm{do}(t)) p(y \mid \mathrm{do}(m)). \tag{9.14}$$

由于 T 到 M 不存在后门路径，$p(m \mid \mathrm{do}(t)) = p(m \mid t)$。此外，根据命题 9.3，$\{T\}$ 是 M 对 Y 效应的有效调整集，因此

$$p(y \mid \mathrm{do}(m)) = \sum_{t'} p(t') p(y \mid m, t'). \tag{9.15}$$

代入后即得到式 (9.13)。

我们指出，这里展示的只是前门调整的最简单形式，足以传达主要思想。只要关于中介变量的条件仍然满足，它也可以扩展以纳入已观测协变量 X。

工具变量（IV）。 第二种处理隐藏混杂的因果推理情形基于工具变量的思想 [2, 29, 160]，见图 10(b)。IV 方法依赖一个特殊的已观测变量 I，称为工具变量。

定义 9.6 (IV). *如果以下三个条件全部成立，那么变量 I 是估计隐藏变量 H 混杂下治疗 T 对结果 Y 效应的有效工具变量：(i) $I \perp\!\!\!\perp H$；(ii) $I \not\perp\!\!\!\perp T$；(iii) $I \perp\!\!\!\perp Y \mid T$。*

译注： 上述条件（iii）照原文保留，但其作为排除限制的表述需要核查。在图 10(b) 的 $I \to T \leftarrow H \to Y$ 路径中，对碰撞点 T 条件化通常会打开该路径；因此即便工具变量没有绕过 T 对 Y 的因果路径，也不能一般性地推出 $I \perp\!\!\!\perp Y \mid T$。这项疑点不否定其他条件下的工具变量方法。

条件（i）指出工具变量独立于任何隐藏混杂因素 H。由于这一假设不能检验，在实践中使用某个变量作为 IV 必须有背景知识支持。条件（ii）和（iii）分别指出工具变量与治疗相关，以及它只通过 T 影响结果，分别称为相关性和排除限制。

给定有效 IV，我们采用两阶段过程：首先通过从 I 预测 T，得到独立于 H 的治疗变量 T 的估计 $\hat{T}$。由此创建一个没有混杂的治疗版本后，再将 Y 对 $\hat{T}$ 回归即可揭示正确的因果效应。我们用一个治疗变量连续的简单线性模型说明这一思想，其中因果效应可以通过两阶段最小二乘（2SLS）获得。

例 9.7 (使用 2SLS 的线性 IV). *考虑由下式定义的线性 SCM:*

$$T := aI + bH + U_T, \qquad Y := cH + dT + U_Y,$$

其中 U_T, U_Y 是独立噪声项。由于 $I \perp\!\!\!\perp H$，将 T 对 I 线性回归可通过 $\hat{T} = aI$ 恢复系数 a。将 T 代入 Y 的结构方程得到

$$Y := daI + (c + bd)H + U_Y + dU_T.$$

随后将 Y 对 $\hat{T} = aI$ 作第二次线性回归，可以恢复因果效应 d，因为 $(I \perp\!\!\!\perp H) \Rightarrow (\hat{T} \perp\!\!\!\perp H)$；而直接将 Y 对 T 回归会得到不同结果，因为 $T \not\perp\!\!\!\perp H$。

工具变量已被广泛研究，存在比上述简单例子更复杂的版本，允许非线性交互与已观测协变量。

讨论了处理隐藏混杂的一些特殊情形后，我们简要介绍一种处理违反重叠性假设的技术。

回归不连续设计。 在回归不连续设计（RDD）中，治疗分配机制表现得像一个阈值函数，即倾向得分不连续 [60]。在最简单的情形下，分配治疗还是对照由一个观测得分 S 是否高于阈值 s_0 决定：$T := \mathbf{1}\{S \geq s_0\}$。该得分又依赖其他可能被观测也可能未被观测的协变量。例如，可能为患者分配一个风险得分，只有得分超过给定阈值时才开具治疗。由于得分可能由其他机构分配，通常并非所有相关协变量 H 都被观测。然而，假设治疗决定只依赖得分，例如因为医生遵循官方规则。此类简单 RDD 情形的因果图见图 10(c)。

虽然原则上得分 S 构成有效调整集，但 RDD 的问题是缺乏重叠性：低得分患者总是被分配 $T = 0$，高得分患者总是被分配 $T = 1$。因此，协变量调整、匹配或加权方法都不适用。RDD 的总体思想是通过比较决策阈值 s_0 的小邻域内的观测来克服这一挑战，其动机是：得分接近但位于 s_0 两侧的患者，只有是否接受治疗这一项差别。例如，如果 $[0, 1]$ 上得分的治疗阈值为 0.5，那么得分为 0.49 和 0.51 的患者可以比较，并可视为来自 RCT 的样本。因此，（最简单形式的）RDD 关注 $s \in [s_0 - \epsilon, s_0 + \epsilon]$ 时回归函数 $\mathbb{E}[Y \mid S = s, T = t(s)] = f(s)$ 的差异，其中 $\epsilon > 0$ 很小。

半同胞回归与系外行星探测。 本节最后讨论一个真实世界应用：在有混杂的加性噪声模型中进行因果推理。NASA 的开普勒空间望远镜于 2009 年发射，最初在四年内观测了 150000 颗恒星，寻找系外行星凌星事件。这类事件中，行星部分遮挡其宿主恒星，使亮度略微下降，而下降幅度通常比望远镜误差的影响小好几个数量级。在观察恒星光变曲线时，我们注意到，相隔数光年的恒星之间往往共享噪声结构。由于这些恒星不可能直接相互作用，显然共享信息来自作为混杂因素的望远镜。因此，我们设计了一种方法：(a) 将感兴趣的恒星对一组大量其他恒星回归，这些恒星经过选择，其测量值不包含关于目标恒星天体物理信号的信息；(b) 去除该回归结果以消除望远镜的影响。[14]

该方法称为“半同胞”回归，因为目标与预测变量共享一个父节点，即望远镜。对于加性噪声模型（具体来说，观测到的光变曲线是未知天体物理信号与望远镜噪声某个未知函数之和），在假设原则上可以根据其他恒星预测望远镜对目标恒星的影响的条件下，该方法以几乎处处的意义恢复表示天体物理信号的随机变量，差一个常数偏移 [132]。

2013 年，开普勒航天器发生技术故障，仅剩两个正常工作的反作用轮，不足以维持原开普勒任务所需的精确空间定向。NASA 决定使用剩余燃料进行进一步观测，但系统误差比以前显著更大——这恰好为我们专门消除这类误差的方法提供了良机。我们为方法增加了系外行星凌星模型以及高效搜索光变曲线的方式，进而发现 36 颗候选行星 [32]，其中 21 颗后来被确认为真正的系外行星 [92]。四年后，天文学家在系外行星 K2-18b 的大气中发现水的踪迹——这是首次在宜居带内、即允许液态水存在的系外行星上作出此类发现 [10, 151]。这颗行星后来被发现正是在我们的工作 [32] 中最早探测到的一颗（系外行星候选体 EPIC 201912552）。

10 当前研究与开放问题

信息守恒。 我们曾指出，信息处理的机械化目前所起的作用，与早期工业革命中能量处理的机械化相似 [125]。我们目前对信息的理解相当不完整，正如第一次和第二次工业革命期间人们对能量的理解一样。对能量的深刻现代理解始于 Emmy Noether 及这样的认识：能量守恒源自物理基本定律的一种对称性（或协变性），即无论我们如何平移时间，定律看起来都相同。人们可以认为，经过适当概念化的信息也应当是守恒量，而且这也可能是对称性的结果。上文讨论的不变性 / 独立性概念或许能在这方面发挥作用。

在 Einstein 于广义相对论中提供更深层的联系之前，质量似乎扮演着两个根本不同的角色（惯性与引力）。值得注意的是，因果性在对称的统计互信息概念之下引入了一个复杂性层次。Shannon [138] 在讨论信源编码与信道编码时指出：“这一对偶性还可以进一步追溯，并与过去和未来以及控制与知识概念之间的对偶有关。因此，我们可以知道过去，却不能控制过去；我们可以控制未来，却不知道未来。”

什么是对象？ 按照独立同分布的模式识别范式，机器学习通过从大量观测中提取模式来学习对象。另一种互补视角可以将对象看作能够被分别操纵或干预的模块 [149]。通过对象在变换下的行为定义对象的思想，在从心理学到数学的诸多领域都产生了影响 [74, 88]。

[14]对于时间上局部化的事件（例如系外行星凌星），我们进一步论证，对恰当选择的该恒星自身的过去和未来值同样成立，因此它们也可用作预测变量。

因果表征学习。 回过头看，人工智能最初试图通过人编写的程序实现智能，这似乎有些天真，因为现有智能系统的例子看起来过于复杂，无法用这种方式实现。然而，还有一个同样重要的问题：经典人工智能假定算法所依据的符号由人事先提供。在构建国际象棋程序时，显然算法操作的是棋盘位置和棋子；但如果我们想解决非结构化环境中的真实世界问题（例如识别口语），哪些东西构成要处理的基本符号并不清楚。传统因果发现和推理假定基本单元是由因果图连接的

经典人工智能： 符号事先给定；规则事先给定。

机器学习： 从数据学习表征（符号）；只包含统计信息。

因果建模： 结构因果模型假定因果变量（符号）已给定。

因果表征学习： 捕捉干预、推理和规划——“思考是在想象的空间中行动”（Konrad Lorenz）。

图 11: 因果表征学习旨在自动学习不仅包含统计信息，而且支持干预、推理和规划的表征。该领域的长期目标是学习支持人工智能的因果世界模型，或复杂系统的因果数字孪生。

随机变量。然而，真实世界的观测最初通常并未组织成这样的单元。例如，允许因果推理的图像对象首先需要被发现 [84, 85, 149, 157]。新兴的因果表征学习领域致力于从数据中学习这些变量，正如机器学习超越符号人工智能，不再要求算法所操作的符号必须事先给定（见图 11）。

有时，可以通过对微观模型粗粒化来定义对象或变量及连接它们的结构模型，所用模型包括微观 SCM [123]、常微分方程 [122] 和时间聚合的时间序列 [37]。虽然经济学、医学或心理学中的大多数因果模型使用的是更基本概念的抽象变量，但要给出粗粒化变量具有带定义良好的干预的因果模型的一般条件，仍是一项挑战 [15, 16, 123]。识别适合因果模型的单元这一任务，与现代机器学习为数据学习有意义表征的总体目标一致，其中“有意义”可以指稳健、可迁移、可解释、可说明或公平 [70, 71, 72, 77, 155, 162]。为了结合结构因果建模（定义 4.4）与表征学习，我们可以尝试设计机器学习模型：其输入可能是高维且非结构化的，但内部运作（部分地）受 SCM 支配。

设高维、低层观测为 $\mathbf{X} = (X_1, \dots, X_d)$。

假设它可以由少量未观测或潜在变量 $\mathbf{S} = (S_1, \dots, S_n)$ 解释，其中 $n \ll d$；具体而言，$\mathbf{X}$ 由对 $\mathbf{S}$ 应用单射 $g : \mathbb{R}^n \to \mathbb{R}^d$ 生成（见图 12(c)）：

$$\mathbf{X} = g(\mathbf{S}). \tag{10.1}$$

关于式 (10.1) 的一个常见假设是潜变量 S_i 联合独立，例如独立成分分析（ICA）[57]（其中 g 称为混合）或解缠结表征学习 [9]（其中 g 称为解码器）。但在这里，我们想把潜变量 S_i 看作支持干预和推理的因果变量。

因此，S_i 完全可能是相互依赖的，并具有因果分解 (4.1)：

$$p(S_1, \dots, S_n) = \prod_{i=1}^{n} p(S_i \mid \mathrm{PA}_i), \tag{10.2}$$

其由底层（无环）SCM $M = (\mathcal{F}, p_U)$ 诱导，其中 U_i 联合独立，且

$$\mathcal{F} = \{S_i := f_i(\mathrm{PA}_i, U_i)\}_{i=1}^{n}. \tag{10.3}$$

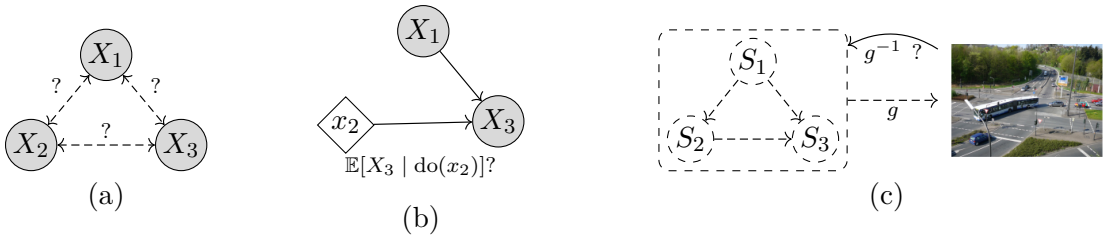


图 12: 不同因果学习任务概览：(a) 因果发现（第 7 节）旨在学习连接一组观测变量的因果图或 SCM；(b) 因果推理（第 9 节）旨在基于观测变量 X_i 上的（部分）因果模型回答干预或反事实查询；(c) 因果表征学习（本节）旨在从可能是高维、低层的观测 $\mathbf{X} = g(\mathbf{S})$ 推断一个由少量高层抽象因果变量 S_i 及其关系组成的因果模型。

我们的目标是学习一个潜在因果模型，它包含：(i) 因果表征 $\mathbf{S} = g^{-1}(\mathbf{X})$；(ii) 相应因果图；(iii) 机制 $p(S_i \mid \mathrm{PA}_i)$ 或 f_i。这是一项具有挑战性的任务，因为它们都不能被直接观察，也不是事先已知；相反，我们通常只能获得 $\mathbf{X}$ 的观测。事实上，在独立同分布情形下没有希望，因为即使潜变量 S_i 独立（且 $n = d$）的更简单情况一般也不可识别（即式 (10.1) 中 g 为任意非线性函数时）：独立性甚至不足以约束问题，使我们能够在对 S_i 的排列和逐元素可逆变换等简单模糊类意义下唯一恢复或识别真实的 S_i [58]。

为了将因果表征学习与式 (10.1) 中潜变量独立、已被充分研究的 ICA 情形联系起来，我们可以考虑（无环）SCM 的所谓简约形式：按照因果图的拓扑顺序递归代入结构赋值 (10.3)，就可以把潜在因果变量 $\mathbf{S}$ 仅写成噪声变量的函数

$$\mathbf{S} = f_{\mathrm{rf}}(\mathbf{U}). \tag{10.4}$$

由于无环性，这一映射 $f_{\mathrm{rf}} : \mathbb{R}^n \to \mathbb{R}^n$ 的 Jacobian 是下三角的（无损一般性地重新排列 S_i 后可能如此）。然而，式 (10.4) 所含信息严格少于式 (10.3)：虽然它们产生相同的分布 (10.2)，前者不再自然地支持对 S_i 的干预，而只支持改变噪声分布 p_U（所谓软干预的一个例子 [30]）。同时，简约形式 (10.4) 使我们可以将式 (10.1) 改写为

$$\mathbf{X} = g \circ f_{\mathrm{rf}}(\mathbf{U}). \tag{10.5}$$

从这一角度看，学习简约形式 (10.4) 的任务可看作非线性 ICA（即式 (10.1) 中潜变量独立）的结构化形式，其中我们还希望通过 f_{rf} 学习中间表征。然而，如上所述，我们连潜变量独立的问题都无法解决，即无法识别式 (10.5) 中的 $g \circ f_{\mathrm{rf}}$ [58]，更不用说分离 SCM 与混合函数以恢复中间因果表征。

因此，在独立同分布情形下无法解决严格更难的因果表征学习问题、需要额外的因果学习信号，并不令人意外。这引出以下问题：我们如何设计因果训练算法来学习 S_i？除了独立同分布情形，它们还需要哪些额外数据、假设和约束？两个一般思想是：(i) 基于 ICM 原理 5.1，强制学习到的因果机制 $p(S_i \mid \mathrm{PA}_i)$ 或 f_i 之间具有某种（算法）独立性；(ii) 使用异质的（非独立同分布）数据，例如来自多个视图或不同环境、由底层潜在 SCM (10.3) 中的干预产生的数据。下面基于近期工作简述一些更具体的想法。

生成式方法：因果自编码器。 一种方法是尝试用自编码器学习生成式因果模型 (10.1) 和 (10.3)，或其简约形式 (10.4) [73]。自编码器由编码器函数 $q : \mathbb{R}^d \to \mathbb{R}^n$ 和解码器函数 $\hat{g} : \mathbb{R}^n \to \mathbb{R}^d$ 组

成：前者将 $\mathbf{X}$ 映射至潜在“瓶颈”表征（例如包含未解释噪声变量 $\mathbf{U}$），后者映射回观测。例如，解码器可以直接实现式 (10.4) 中的复合 $\hat{g} = g \circ f_{\text{rf}}$。或者，它也可以包含多个模块，分别实现式 (10.1) 和 (10.3)。训练此类自编码器架构的标准过程是最小化重构误差，即在 $\mathbf{X}$ 的观测训练集上满足 $\hat{g} \circ q \approx \text{id}$。如上所述，仅此还不够；为了使其具有因果性质，我们可以对解码器结构施加额外约束 [80]，并通过确保因果机制在问题间保持不变、可以分别干预，尝试使它们独立。

例如，如果我们分别对式 (10.3) 或 (10.4) 模型中的因果变量 S_i 或噪声分布 p_U 进行干预，它仍应产生“有效”的观测；例如可以用生成对抗网络的判别器来评估 [38]。虽然理想情况下我们希望操纵因果变量，另一种干预方式是用从其他输入图像计算出的对应值替换噪声变量，这一过程被称为混合化（hybridization）[11]。另一种可能是，如果我们能够获得多个环境，即在不同条件下收集的数据集，就可以依据稀疏机制偏移原理 5.2，要求变化只能由少数几个 $p(S_i \mid \text{PA}_i)$ 的偏移解释。

判别式方法：自监督因果表征学习。 另一种用于无监督表征学习的机器学习方法并非基于生成建模，而是具有判别性质，即使用数据增强的自监督学习。其主要思想是对观测施加一些人工设计的变换，生成被认为与原观测共享主要语义特征的增强视图（例如对图像作随机裁剪或模糊）。随后，通过最大化由增强关联的视图的编码之间的相似性，同时强制无关视图的编码具有多样性，直接学习表征。在最近的一项工作中 [158]，我们试图在理论上更好地理解这一方法，并研究它学习因果表征的潜力。

从式 (10.1) 出发，我们假定潜在因果模型 $S_c \to S_s$，其中 S_c 是（可能为多元的）内容变量，定义为表征 $\mathbf{S} = (S_c, S_s)$ 中高层语义部分，并假设它在不同视图间不变；S_s 是（可能为多元的）风格变量，定义为表征中可能变化的其余部分。在这种情形下，数据增强可以自然地解释为给定原始视图、对风格变量作假设性干预后的反事实。可以证明，在此情况下并满足一些技术假设时，常见的对比式自监督学习算法 [19, 45, 152] 以及适当约束的生成模型能够在相差一个可逆变换的意义下分离或恢复真实内容变量 S_c。通过将这一方法扩展为使用同一观测的多个增强视图，并将它们与潜在 SCM 中不同的反事实联系起来，或许能够恢复更细粒度的因果表征。

独立机制分析。 我们还研究了 [40] ICM 原理 5.1 对式 (10.1) 这类无监督表征学习任务可能有多大帮助，特别是在对混合函数 g 施加额外约束方面。事实表明，当 $\mathbf{S}$ 未被观测时，$p(\mathbf{S})$ 与混合 g 之间的独立性——例如按照第 5 节图 6 和文献 [68] 中讨论的方法度量——不会施加非平凡约束，即便像 ICA 中那样假设各 S_i 独立也是如此。然而，通过将每个 S_i 视为独立影响观测分布，我们对混合 g 的偏导数 $\partial g / \partial S_i$ 之间提出另一种独立性，它在几何上可解释为 g 的 Jacobian 各列的正交条件。由此得到的独立机制分析（IMA）方法排除了一些上文提到的非线性 ICA 不可识别性的常见例子 [58, 83]。由于 IMA 不要求源相互独立，它也可能是因果表征学习算法的有用约束。

学习可迁移机制与多任务学习。 机器学习擅长独立同分布情形；只要我们为每个单独问题都有独立同分布数据（第 2 节），通过使用高容量学习算法，就能在许多问题上取得出色表现。然而，自然智能擅长跨任务和情形泛化。假设我们想构建一个能够在多个环境中解决多个任务的系统。如果把学习看作数据压缩，那么该系统利用可跨任务和环境适用、因而只需存储一次的组件，将是合理的 [125]。

事实上，复杂世界中的人工或自然智能体面临资源限制。这涉及训练数据：我们对每个任务或域都只有有限数据，因此需要寻找汇集或重用数据的方法，这与当前大规模人工标注的行业实践形成鲜明对比。它也涉及计算资源：动物大脑所使用的空间、能量等资源受到限制，进化神经科学中也有脑区被重新用于其他用途的例子。当机器学习系统嵌入可能体积小且使用电池供电的物理设备时，也会受到类似约束。因此，能够在真实世界稳健解决一系列问题的通用人工智能模型，很可能需要重用组件，而这要求组件跨任务和环境保持稳健 [127, 133]。这需要一种模块可最大限度重用的结构。一种优雅做法是使用反映世界本身模块性的模块化结构。换句话说，如果世界中起作用的机制在一系列环境、任务和情形中发挥相似作用，那么模型采用相应的计算模块将是明智的 [39]。

例如，如果自然光照变化（太阳位置、云层等）使视觉环境的亮度条件跨越几个数量级，我们神经系统的视觉处理算法就应当使用能够消去这些变化的方法，而不是为每一种光照条件建立单独的一套对象识别器。假如我们的大脑通过某种增益控制机制对光照变化建模，那么这个机制本身不必与产生亮度差异的物理机制有任何关系。然而，它在模块结构中所起的作用，会对应于物理机制在世界模块结构中的作用——换言之，它将表征该物理机制。因此，寻找最通用而又紧凑的模型，会自动产生一种偏向：偏向表现出与我们无法直接认识的世界之间某些结构同构形式的模型。

学习此类模型的一种合理归纳偏置是寻找独立因果机制 [82]，竞争性训练可以在其中发挥作用：对于模式识别任务，学习包含独立机制的因果模型有助于跨差异显著的域迁移模块 [99]。

干预式世界模型、代理模型、数字孪生与推理。 现代表征学习擅长学习保留相关统计性质的数据表征 [9, 79]。然而，它并不考虑变量的因果性质，即它不关心所分析或重构变量的干预性质。展望未来，因果性将在推动表征学习进入下一阶段方面发挥主要作用：超越统计依赖结构的表征，转向支持干预、规划和推理的模型。这将实现 Konrad Lorenz 将思考视为在想象空间中行动的观点。它还将提供学习因果数字孪生的方法，使其超越由机器学习训练的代理模型所捕捉的统计依赖关系。

代理建模的思想是：我们可能面对一个复杂现象，并能够获得计算成本高昂的模拟数据。如果相关映射（例如从参数设定到目标量的映射）可以从数据中拟合，我们就可以使用机器学习，而这往往可以使其加速数个数量级。这样的加速可以从质上改变模型的可用性：例如，我们最近构建了一个系统，将引力波测量映射为黑洞并合事件的物理参数概率分布，其中包括天空位置 [27]。由于这一模型只需数秒便可求值，我们可以在探测到引力波事件后立即使用望远镜开始电磁后续观测，从而能够分析瞬态事件。

展望未来，我们预计代理建模将受益于遵循因果分解 (4.1)，把总体依赖结构分解为机制（即因果条件分布）。然后，我们可以通过独立地对各机制建模来构建系统的总体模型，每个机制都使用最优方法。有些条件分布可能已经具有解析表达；有些如果保持不变，或许可以从相关问题中迁移。对于其中一些，我们可能有真实数据来估计；对于另一些，则可能需要借助模拟，并可能使用代理模型进行拟合。

如果模型需要完整捕捉所有可能干预的效果，那么所有组件都应当如上所述沿因果方向拟合，即拟合因果机制。这样的模型便能够使用第 4 节和第 9 节介绍的全部因果推理工具，例如计算干预分布，以及对于 SCM 计算反事实分布。另一方面，如果一个模型只需捕捉部分可能的干预，并对其他变量以纯预测 / 观测模式使用，那么我们也可以使用并拟合某些非因果模块，即

使用介于式 (4.1) 和式 (4.2) 之间的分解。

我们相信，这一总体框架将成为一种有原则且强有力的方法：结合一系列方法，并根据各自优势加以运用，以构建这类（因果）数字孪生或因果代理模型。

结束语。 所讨论的大多数领域仍处于初期，上述论述也带有个人兴趣与知识的偏向。面对当前机器学习热潮，对于机器学习能够做到什么、进而对于人工智能当前的状态，保持一定的谦逊有很多理由——困难问题尚未解决，这使得该领域的基础研究更加令人兴奋。

致谢

衷心感谢蒂宾根因果团队所有过去和现在的成员，以及对稿件提供反馈的 Cian Eastwood 和 Elias Bareinboim。

参考文献

[1] J. Aldrich, Autonomy. Oxf. Econ. Pap. 41 (1989), 15–34.

[2] J. D. Angrist, G. W. Imbens, and D. B. Rubin, Identification of causal effects using instrumental variables. J. Amer. Statist. Assoc. 91 (1996), no. 434, 444–455.

[3] M. Arjovsky, L. Bottou, I. Gulrajani, and D. Lopez-Paz, Invariant risk minimization. 2019, arXiv:1907.02893.

[4] E. Bareinboim and J. Pearl, Transportability from multiple environments with limited experiments: completeness results. In Advances in neural information processing systems 27, pp. 280–288, Curran Associates, Inc., 2014.

[5] E. Bareinboim and J. Pearl, Causal inference and the data-fusion problem. Proc. Natl. Acad. Sci. 113 (2016), no. 27, 7345–7352.

[6] S. Bauer, B. Schölkopf, and J. Peters, The arrow of time in multivariate time series. In Proceedings of the 33nd international conference on machine learning 48, pp. 2043–2051, PMLR, 2016.

[7] M. Belkin, D. Hsu, S. Ma, and S. Mandal, Reconciling modern machine learning practice and the bias-variance trade-off. 2018, arXiv:1812.11118.

[8] S. Ben-David, T. Lu, T. Luu, and D. Pál, Impossibility theorems for domain adaptation. In Proceedings of the international conference on artificial intelligence and statistics 13 (AISTATS), pp. 129–136, PMLR, 2010.

[9] Y. Bengio, A. Courville, and P. Vincent, Representation learning: A review and new perspectives. IEEE Trans. Pattern Anal. Mach. Intell. 35 (2013), no. 8, 1798–1828.

[10] B. Benneke, I. Wong, C. Piaulet, H. A. Knutson, I. J. M. Crossfield, J. Lothringer, C. V. Morley, P. Gao, T. P. Greene, C. Dressing, D. Dragomir, A. W. Howard, P. R. McCullough, E. M. R. K. J. J. Fortney, and J. Fraine, Water vapor on the habitable-zone exoplanet K2-18b. 2019, arXiv:1909.04642.

[11] M. Besserve, A. Mehrjou, R. Sun, and B. Schölkopf, Counterfactuals uncover the modular structure of deep generative models. In International conference on learning representations, OpenReview.net, 2020.

[12] M. Besserve, N. Shajarisales, B. Schölkopf, and D. Janzing, Group invariance principles for causal generative models. In Proceedings of the 21st international conference on artificial intelligence and statistics (AISTATS), pp. 557–565, PMLR, 2018.

[13] S. Bongers, P. Forré, J. Peters, and J. M. Mooij, Foundations of structural causal models with cycles and latent variables. Ann. Statist. 49 (2021), no. 5, 2885–2915.

[14] D. Buchsbaum, S. Bridgers, D. Skolnick Weisberg, and A. Gopnik, The power of possibility: Causal learning, counterfactual reasoning, and pretend play. Philos. Trans. R. Soc. B, Biol. Sci. 367 (2012), no. 1599, 2202–2212.

[15] K. Chalupka, F. Eberhardt, and P. Perona, Multi-level cause-effect systems. In Artificial intelligence and statistics, pp. 361–369, PMLR, 2016.

[16] K. Chalupka, F. Eberhardt, and P. Perona, Causal feature learning: an overview. Behaviormetrika 44 (2017), no. 1, 137–164.

[17] O. Chapelle, B. Schölkopf, and A. Zien (eds.), Semi-supervised learning. MIT Press, Cambridge, MA, USA, 2006.

[18] C. R. Charig, D. R. Webb, S. R. Payne, and J. E. Wickham, Comparison of treatment of renal calculi by open surgery, percutaneous nephrolithotomy, and extracorporeal shockwave lithotripsy. Br. Med. J. (Clin. Res. Ed.) 292 (1986), no. 6524, 879–882.

[19] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, A simple framework for contrastive learning of visual representations. 2020, arXiv:2002.05709.

[20] D. M. Chickering, Learning Bayesian networks is NP-complete. In Learning from data, pp. 121–130, Springer, 1996.

[21] D. M. Chickering, Optimal structure identification with greedy search. J. Mach. Learn. Res. 3 (2002), 507–554.

[22] G. F. Cooper and E. Herskovits, A Bayesian method for the induction of probabilistic networks from data. Mach. Learn. 9 (1992), no. 4, 309–347.

[23] D. R. Cox, Planning of experiments, Wiley, 1958.

[24] P. Daniušis, D. Janzing, J. M. Mooij, J. Zscheischler, B. Steudel, K. Zhang, and B. Schölkopf, Inferring deterministic causal relations. In Proceedings of the 26th annual conference on uncertainty in artificial intelligence (UAI), pp. 143–150, AUAI Press, 2010.

[25] A. P. Dawid, Conditional independence in statistical theory. J. R. Stat. Soc. Ser. B. 41 (1979), no. 1, 1–31.

[26] A. P. Dawid, Causal inference without counterfactuals. J. Amer. Statist. Assoc. 95 (2000), no. 450, 407–424.

[27] M. Dax, S. R. Green, J. Gair, J. H. Macke, A. Buonanno, and B. Schölkopf, Realtime gravitational-wave science with neural posterior estimation. Phys. Rev. Lett. 127 (2021), no. 24.

[28] L. Devroye, L. Györfi, and G. Lugosi, A probabilistic theory of pattern recognition. Appl. Math. 31, Springer, New York, NY, 1996.

[29] V. Didelez, S. Meng, and N. A. Sheehan, Assumptions of IV methods for observational epidemiology. Statist. Sci. 25 (2010), 22–40.

[30] F. Eberhardt and R. Scheines, Interventions and causal inference. Philos. Sci. 74 (2007), no. 5, 981–995.

[31] R. A. Fisher, The design of experiments 2. Oliver & Boyd, Edinburgh & London, 1937.

[32] D. Foreman-Mackey, B. T. Montet, D. W. Hogg, T. D. Morton, D. Wang, and B. Schölkopf, A systematic search for transiting planets in the K2 data. Astrophys. J. 806 (2015), no. 2.

[33] K. Fukumizu, A. Gretton, X. Sun, and B. Schölkopf, Kernel measures of conditional dependence. In Advances in neural information processing systems, pp. 489–496, Curran Associates, Inc., 2008.

[34] D. Geiger and D. Heckerman, Learning Gaussian networks. In Proceedings of the tenth international conference on uncertainty in artificial intelligence, pp. 235–243, AUAI Press, 1994.

[35] D. Geiger and J. Pearl, Logical and algorithmic properties of independence and their application to Bayesian networks. Ann. Math. Artif. Intell. 2 (1990), 165–178.

[36] M. Gong, K. Zhang, T. Liu, D. Tao, C. Glymour, and B. Schölkopf, Domain adaptation with conditional transferable components. In Proceedings of the 33nd international conference on machine learning, pp. 2839–2848, PMLR, 2016.

[37] M. Gong, K. Zhang, B. Schölkopf, C. Glymour, and D. Tao, Causal discovery from temporally aggregated time series. In Proceedings of the thirty-third conference on uncertainty in artificial intelligence, pp. 1066–1075, AUAI Press, 2017.

[38] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, Generative adversarial nets. In Advances in neural information processing systems 27, pp. 2672–2680, Curran Associates, Inc., 2014.

[39] A. Goyal, A. Lamb, J. Hoffmann, S. Sodhani, S. Levine, Y. Bengio, and B. Schölkopf, Recurrent independent mechanisms. In International conference on learning representations, OpenReview.net, 2021.

[40] L. Gresele, J. von Kügelgen, V. Stimper, B. Schölkopf, and M. Besserve, Independent mechanism analysis, a new concept? In Advances in neural information processing systems 34, Curran Associates, Inc., 2021.

[41] A. Gretton, K. M. Borgwardt, M. Rasch, B. Schölkopf, and A. J. Smola, A kernel method for the two-sample-problem. In Advances in neural information processing systems 19, pp. 513–520, Curran Associates, Inc., 2007.

[42] A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf, Measuring statistical dependence with Hilbert–Schmidt norms. In Algorithmic learning theory, pp. 63–78, Springer, 2005.

[43] A. Gretton, K. Fukumizu, C. H. Teo, L. Song, B. Schölkopf, and A. J. Smola, A kernel statistical test of independence. In Advances in neural information processing systems 20, pp. 585–592, Curran Associates, Inc., 2008.

[44] A. Gretton, R. Herbrich, A. Smola, O. Bousquet, and B. Schölkopf, Kernel methods for measuring independence. J. Mach. Learn. Res. 6 (2005), 2075–2129.

[45] U. M. Gutmann and A. Hyvärinen, Noise-contrastive estimation: a new estimation principle for unnormalized statistical models. In International conference on artificial intelligence and statistics, pp. 297–304, PMLR, 2010.

[46] T. Haavelmo, The probability approach in econometrics. Econometrica (1944), iii–115.

[47] D. Heckerman, D. Geiger, and D. M. Chickering, Learning Bayesian networks: the combination of knowledge and statistical data. Mach. Learn. 20 (1995), no. 3, 197–243.

[48] D. Heckerman, C. Meek, and G. Cooper, A Bayesian approach to causal discovery. In Innovations in machine learning, pp. 1–28, Springer, 2006.

[49] M. A. Hernán, D. Clayton, and N. Keiding, The Simpson' s paradox unraveled. Int. J. Epidemiol. 40 (2011), no. 3, 780–785.

[50] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, Beta-VAE: learning basic visual concepts with a constrained variational framework. In International conference on learning representations, OpenReview.net, 2017.

[51] P. W. Holland, Statistics and causal inference. J. Amer. Statist. Assoc. 81 (1986), no. 396, 945–960.

[52] K. D. Hoover, Causality in macroeconomics. Cambridge University Press, 2001.

[53] P. O. Hoyer, D. Janzing, J. M. Mooij, J. Peters, and B. Schölkopf, Nonlinear causal discovery with additive noise models. In Advances in neural information processing systems 21, pp. 689–696, Curran Associates, Inc., 2009.

[54] B. Huang, K. Zhang, J. Zhang, R. Sanchez-Romero, C. Glymour, and B. Schölkopf, Behind distribution shift: mining driving forces of changes and causal arrows. In IEEE 17th international conference on data mining (ICDM 2017), pp. 913–918, IEEE, 2017.

[55] B. Huang, K. Zhang, J. Zhang, J. D. Ramsey, R. Sanchez-Romero, C. Glymour, and B. Schölkopf, Causal discovery from heterogeneous/nonstationary data. J. Mach. Learn. Res. 21 (2020), no. 89, 1–53.

[56] Y. Huang and M. Valtorta, Pearl' s calculus of intervention is complete. In Proceedings of the twenty-second conference on uncertainty in artificial intelligence, pp. 217–224, AUAI Press, 2006.

[57] A. Hyvärinen and E. Oja, Independent component analysis: algorithms and applications. Neural Netw. 13 (2000), no. 4–5, 411–430.

[58] A. Hyvärinen and P. Pajunen, Nonlinear independent component analysis: existence and uniqueness results. Neural Netw. 12 (1999), no. 3, 429–439.

[59] A. Hyvarinen, H. Sasaki, and R. Turner, Nonlinear ICA using auxiliary variables and generalized contrastive learning. In The 22nd international conference on artificial intelligence and statistics, pp. 859–868, PMLR, 2019.

[60] G. W. Imbens and T. Lemieux, Regression discontinuity designs: a guide to practice. J. Econometrics 142 (2008), no. 2, 615–635.

[61] G. W. Imbens and D. B. Rubin, Causal inference in statistics, social, and biomedical sciences. Cambridge University Press, 2015.

[62] D. Janzing, R. Chaves, and B. Schölkopf, Algorithmic independence of initial condition and dynamical law in thermodynamics and causal inference. New J. Phys. 18 (2016), no. 093052, 1–13.

[63] D. Janzing, P. Hoyer, and B. Schölkopf, Telling cause from effect based on highdimensional observations. In Proceedings of the 27th international conference on machine learning, edited by J. Fürnkranz and T. Joachims, pp. 479–486, PMLR, 2010.

[64] D. Janzing, J. Peters, J. M. Mooij, and B. Schölkopf, Identifying confounders using additive noise models. In Proceedings of the 25th annual conference on uncertainty in artificial intelligence (UAI), pp. 249–257, AUAI Press, 2009.

[65] D. Janzing and B. Schölkopf, Causal inference using the algorithmic Markov condition. IEEE Trans. Inf. Theory 56 (2010), no. 10, 5168–5194.

[66] D. Janzing and B. Schölkopf, Semi-supervised interpolation in an anticausal learning scenario. J. Mach. Learn. Res. 16 (2015), 1923–1948.

[67] D. Janzing and B. Schölkopf, Detecting non-causal artifacts in multivariate linear regression models. In Proceedings of the 35th international conference on machine learning (ICML), pp. 2250–2258, PMLR, 2018.

[68] D. Janzing, J. M. Mooij, K. Zhang, J. Lemeire, J. Zscheischler, P. Daniušis, B. Steudel, and B. Schölkopf, Information-geometric approach to inferring causal directions. Artificial Intelligence 182–183 (2012), 1–31.

[69] Z. Jin, J. von Kügelgen, J. Ni, T. Vaidhya, A. Kaushal, M. Sachan, and B. Schölkopf, Causal direction of data collection matters: Implications of causal and anticausal learning for NLP. In Proceedings of the 2021 conference on empirical methods in natural language processing (EMNLP), pp. 9499–9513, Association for Computational Linguistics, 2021.

[70] A.-H. Karimi, B. Schölkopf, and I. Valera, Algorithmic recourse: from counterfactual explanations to interventions. In Conference on fairness, accountability, and transparency, pp. 353–362, ACM, 2021.

[71] A.-H. Karimi, J. von Kügelgen, B. Schölkopf, and I. Valera, Algorithmic recourse under imperfect causal knowledge: a probabilistic approach. In Advances in neural information processing systems 33, pp. 265–277, Curran Associates, Inc., 2020.

[72] N. Kilbertus, M. Rojas Carulla, G. Parascandolo, M. Hardt, D. Janzing, and B. Schölkopf, Avoiding discrimination through causal reasoning. In Advances in neural information processing systems 30, pp. 656–666, Curran Associates, Inc., 2017.

[73] D. P. Kingma and M. Welling, Auto-encoding variational Bayes. 2013, arXiv:1312.6114.

[74] F. Klein, Vergleichende Betrachtungen über neuere geometrische Forschungen. Verlag von Andreas Deichert, Erlangen, 1872.

[75] D. Koller and N. Friedman, Probabilistic graphical models: principles and techniques. MIT Press, 2009.

[76] S. Kpotufe, E. Sgouritsa, D. Janzing, and B. Schölkopf, Consistency of causal inference under the additive noise model. In Proceedings of the 31th international conference on machine learning, pp. 478–486, PMLR, 2014.

[77] M. J. Kusner, J. Loftus, C. Russell, and R. Silva, Counterfactual fairness. In Advances in neural information processing systems 30, pp. 4066–4076, Curran Associates, Inc., 2017.

[78] S. L. Lauritzen, Graphical models. 17. Clarendon Press, 1996.

[79] Y. LeCun, Y. Bengio, and G. Hinton, Deep learning. Nature 521 (2015), no. 7553, 436–444.

[80] F. Leeb, Y. Annadani, S. Bauer, and B. Schölkopf, Structural autoencoders improve representations for generation and transfer. 2020, arXiv:2006.07796.

[81] G. W. Leibniz, Discours de métaphysique, 1686 (cited after Chaitin, 2010).

[82] F. Locatello, D. Vincent, I. Tolstikhin, G. Rätsch, S. Gelly, and B. Schölkopf, Competitive training of mixtures of independent deep generative models. 2018, arXiv:1804.11130.

[83] F. Locatello, S. Bauer, M. Lucic, G. Rätsch, S. Gelly, B. Schölkopf, and O. Bachem, Challenging common assumptions in the unsupervised learning of disentangled representations. In Proceedings of the 36th international conference on machine learning, PMLR, 2019.

[84] F. Locatello, D. Weissenborn, T. Unterthiner, A. Mahendran, G. Heigold, J. Uszkoreit, A. Dosovitskiy, and T. Kipf, Object-centric learning with slot attention. In Advances in neural information processing systems, pp. 11525–11538, Curran Associates, Inc., 2020.

[85] D. Lopez-Paz, R. Nishihara, S. Chintala, B. Schölkopf, and L. Bottou, Discovering causal signals in images. In IEEE conference on computer vision and pattern recognition (CVPR), pp. 58–66, IEEE Computer Society, 2017.

[86] J. Loschmidt, Über den Zustand des Wärmegleichgewichtes eines Systems von Körpern mit Rücksicht auf die Schwerkraft. Sitzungsber. Akad. Wiss. Wien, Math.-Naturwiss. Kl. 73 (1876), 128–142.

[87] C. Lu, Y. Wu, J. M. Hernández-Lobato, and B. Schölkopf, Nonlinear invariant risk minimization: a causal approach. 2021, arXiv:2102.12353.

[88] S. MacLane, Categories for the working mathematician. Springer, New York, 1971.

[89] R. Matthews, Storks deliver babies (p D 0:008). Teach. Stat. 22 (2000), no. 2, 36–38.

[90] C. Meek, Causal inference and causal explanation with background knowledge. In Proceedings of the eleventh conference on uncertainty in artificial intelligence, pp. 403–410, Morgan Kaufmann Publishers Inc., 1995.

[91] F. H. Messerli, Chocolate consumption, cognitive function, and Nobel laureates. N. Engl. J. Med. 367 (2012), no. 16, 1562–1564.

[92] B. T. Montet, T. D. Morton, D. Foreman-Mackey, J. A. Johnson, D. W. Hogg, B. P. Bowler, D. W. Latham, A. Bieryla, and A. W. Mann, Stellar and planetary properties of K2 campaign 1 candidates and validation of 17 planets, including a planet receiving earth-like insolation. Astrophys. J. 809 (2015), no. 1, 25.

[93] R. P. Monti, K. Zhang, and A. Hyvärinen, Causal discovery with general nonlinear relationships using non-linear ICA. In Uncertainty in artificial intelligence, pp. 186–195, PMLR, 2020.

[94] J. M. Mooij, D. Janzing, T. Heskes, and B. Schölkopf, On causal discovery with cyclic additive noise models. In Advances in neural information processing systems 24 (NIPS), pp. 639–647, Curran Associates, Inc., 2011.

[95] J. M. Mooij, D. Janzing, J. Peters, and B. Schölkopf, Regression by dependence minimization and its application to causal inference. In Proceedings of the 26th international conference on machine learning (ICML), pp. 745–752, PMLR, 2009.

[96] J. M. Mooij, D. Janzing, and B. Schölkopf, From ordinary differential equations to structural causal models: the deterministic case. In Proceedings of the 29th annual conference on uncertainty in artificial intelligence (UAI), pp. 440–448, AUAI Press, 2013.

[97] J. M. Mooij, J. Peters, D. Janzing, J. Zscheischler, and B. Schölkopf, Distinguishing cause from effect using observational data: methods and benchmarks. J. Mach. Learn. Res. 17 (2016), no. 32, 1–102.

[98] J. S. Neyman, On the application of probability theory to agricultural experiments. Essay on principles. Section 9. Ann. Agric. Sci. 10 (1923), 1–51. (Translated and edited by D. M. Dabrowska and T. P. Speed, Statist. Sci. 5 (1990), 465–480).

[99] G. Parascandolo, N. Kilbertus, M. Rojas-Carulla, and B. Schölkopf, Learning independent causal mechanisms. In Proceedings of the 35th international conference on machine learning (PMLR) 80, pp. 4036–4044, PMLR, 2018.

[100] J. Park and K. Muandet, A measure-theoretic approach to kernel conditional mean embeddings. In Advances in neural information processing systems 33 (NEURIPS 2020), pp. 21247–21259, Curran Associates, Inc., 2020.

[101] J. Pearl, Bayesian networks: a model of self-activated memory for evidential reasoning. In Proceedings of the 7th conference of the cognitive science society, pp. 329–334, University of California (Los Angeles), Computer Science Department, 1985.

[102] J. Pearl, Causal diagrams for empirical research. Biometrika 82 (1995), no. 4, 669–-688.

[103] J. Pearl, Direct and indirect effects. In Proceedings of the seventeenth conference on uncertainty in artificial intelligence, pp. 411–420, AUAI Press, 2001.

[104] J. Pearl, Causality: models, reasoning, and inference. 2nd edn., Cambridge University Press, New York, NY, 2009.

[105] J. Pearl, Comment: understanding Simpson' s paradox. Amer. Statist. 68 (2014), no. 1, 8–13.

[106] J. Pearl and E. Bareinboim, External validity: From do-calculus to transportability across populations. Statist. Sci. 29 (2014), no. 4, 579–595.

[107] J. Pearl and D. Mackenzie, The book of why: the new science of cause and effect. Basic Books, 2018.

[108] J. Pearl and A. Paz, Confounding equivalence in causal inference. J. Causal Inference 2 (2014), no. 1, 75-–93.

[109] J. Pearl and T. Verma, A theory of inferred causation. In Principles of knowledge representation and reasoning: proceedings of the second international conference 2, p. 441, Morgan Kaufmann, 1991.

[110] J. Peters, P. Bühlmann, and N. Meinshausen, Causal inference by using invariant prediction: identification and confidence intervals. J. R. Stat. Soc. Ser. B. Stat. Methodol. 78 (2016), no. 5, 947–1012.

[111] J. Peters, D. Janzing, and B. Schölkopf, Elements of causal inference –foundations and learning algorithms. MIT Press, Cambridge, MA, USA, 2017.

[112] J. Peters, J. M. Mooij, D. Janzing, and B. Schölkopf, Identifiability of causal graphs using functional models. In Proceedings of the 27th annual conference on Uncertainty in Artificial Intelligence (UAI), pp. 589–598, AUIA Press, 2011.

[113] J. Peters, J. M. Mooij, D. Janzing, and B. Schölkopf, Causal discovery with continuous additive noise models. J. Mach. Learn. Res. 15 (2014), 2009–2053.

[114] N. Pfister, P. Bühlmann, B. Schölkopf, and J. Peters, Kernel-based tests for joint independence. J. R. Stat. Soc. Ser. B. Stat. Methodol. 80 (2018), no. 1, 5–31.

[115] K. Popper, The logic of scientific discovery. 1959.

[116] H. Reichenbach, The direction of time. University of California Press, Berkeley, CA, 1956.

[117] J. Robins, A new approach to causal inference in mortality studies with a sustained exposure period—application to control of the healthy worker survivor effect. Math. Model. 7 (1986), no. 9–12, 1393–1512.

[118] J. M. Robins, M. A. Hernan, and B. Brumback, Marginal structural models and causal inference in epidemiology. Epidemiology 11 (2000), no. 5, 550–560.

[119] R. W. Robinson, Counting labeled acyclic digraphs, new directions in the theory of graphs. In Proc. third Ann Arbor conf., Univ. Michigan, Ann Arbor, MI, 1971, pp. 239–273, Academic Press, 1973.

[120] M. Rojas-Carulla, B. Schölkopf, R. Turner, and J. Peters, Invariant models for causal transfer learning. J. Mach. Learn. Res. 19 (2018), no. 36, 1–34.

[121] P. R. Rosenbaum and D. B. Rubin, The central role of the propensity score in observational studies for causal effects. Biometrika 70 (1983), no. 1, 41–55.

[122] P. K. Rubenstein, S. Bongers, B. Schölkopf, and J. M. Mooij, From deterministic ODEs to dynamic structural causal models. In Proceedings of the 34th conference on uncertainty in artificial intelligence (UAI), pp. 114–123, AUAI Press, 2018.

[123] P. K. Rubenstein, S. Weichwald, S. Bongers, J. M. Mooij, D. Janzing, M. GrosseWentrup, and B. Schölkopf, Causal consistency of structural equation models. In Proceedings of the thirty-third conference on uncertainty in artificial intelligence, pp. 808–817, AUAI Press, 2017.

[124] D. B. Rubin, Estimating causal effects of treatments in randomized and nonrandomized studies. J. Educ. Psychol. 66 (1974), no. 5, 688.

[125] B. Schölkopf, Causality for machine learning. 2019, arXiv:1911.10500. To appear in: R. Dechter, J. Halpern, and H. Geffner, Probabilistic and causal inference: the works of Judea Pearl. ACM books, 2019.

[126] B. Schölkopf, R. Herbrich, and A. J. Smola, A generalized representer theorem. In Annual conference on computational learning theory, edited by D. Helmbold and R. Williamson, pp. 416–426, Lecture Notes in Comput. Sci. 2111, Springer, Berlin, 2001.

[127] B. Schölkopf, D. Janzing, and D. Lopez-Paz, Causal and statistical learning. Oberwolfach Rep. 13 (2016), no. 3, 1896–1899.

[128] B. Schölkopf, D. Janzing, J. Peters, E. Sgouritsa, K. Zhang, and J. M. Mooij, On causal and anticausal learning. In Proceedings of the 29th international conference on machine learning (ICML), pp. 1255–1262, PMLR, 2012.

[129] B. Schölkopf, K. Muandet, K. Fukumizu, S. Harmeling, and J. Peters, Computing functions of random variables via reproducing kernel Hilbert space representations. Stat. Comput. 25 (2015), no. 4, 755–766.

[130] B. Schölkopf and A. J. Smola, Learning with kernels. MIT Press, Cambridge, MA, 2002.

[131] B. Schölkopf, B. K. Sriperumbudur, A. Gretton, and K. Fukumizu, RKHS representation of measures applied to homogeneity, independence, and Fourier optics. Oberwolfach Rep. 30 (2008), 42–44.

[132] B. Schölkopf, D. Hogg, D. Wang, D. Foreman-Mackey, D. Janzing, C.-J. SimonGabriel, and J. Peters, Modeling confounding by half-sibling regression. Proc. Natl. Acad. Sci. 113 (2016), no. 27, 7391–7398.

[133] B. Schölkopf, F. Locatello, S. Bauer, N. R. Ke, N. Kalchbrenner, A. Goyal, and Y. Bengio, Toward causal representation learning. Proc. IEEE 109 (2021), no. 5, 612–634.

[134] G. Schwarz, et al., Estimating the dimension of a model. Ann. Statist. 6 (1978), no. 2, 461–464.

[135] R. D. Shah and J. Peters, The hardness of conditional independence testing and the generalised covariance measure. Ann. Statist. 48 (2020), no. 3, 1514–1538.

[136] N. Shajarisales, D. Janzing, B. Schölkopf, and M. Besserve, Telling cause from effect in deterministic linear dynamical systems. In Proceedings of the 32nd international conference on machine learning (ICML), pp. 285–294, PMLR, 2015.

[137] U. Shalit, F. D. Johansson, and D. Sontag, Estimating individual treatment effect: generalization bounds and algorithms. In International conference on machine learning, pp. 3076–3085, PMLR, 2017.

[138] C. E. Shannon, Coding theorems for a discrete source with a fidelity criterion. In IRE international convention records 7, pp. 142–163, Wiley-IEEE Press, 1959.

[139] S. Shimizu, P. O. Hoyer, A. Hyvärinen, and A. J. Kerminen, A linear nonGaussian acyclic model for causal discovery. J. Mach. Learn. Res. 7 (2006), 2003–2030.

[140] I. Shpitser and J. Pearl, Identification of joint interventional distributions in recursive semi-Markovian causal models. In Proceedings of the 21st national conference on artificial intelligence, pp. 1219–1226, AAAI Press, 2006.

[141] I. Shpitser, T. VanderWeele, and J. M. Robins, On the validity of covariate adjustment for estimating causal effects. In Proceedings of the twenty-sixth conference on uncertainty in artificial intelligence, pp. 527–536, AUAI Press, 2010.

[142] E. H. Simpson, The interpretation of interaction in contingency tables. J. Roy. Statist. Soc. Ser. B 13 (1951), no. 2, 238–241.

[143] A. J. Smola, A. Gretton, L. Song, and B. Schölkopf, A Hilbert space embedding for distributions. In Algorithmic learning theory: 18th international conference, pp. 13–31, Springer, 2007.

[144] P. Spirtes, C. Glymour, and R. Scheines, Causation, prediction, and search. 2nd edn., MIT Press, Cambridge, MA, 2000.

[145] W. Spohn, Grundlagen der Entscheidungstheorie. Scriptor, 1978.

[146] I. Steinwart and A. Christmann, Support vector machines. Springer, New York, NY, 2008.

[147] R. Suter, D. Miladinovic, B. Schölkopf, and S. Bauer, Robustly disentangled causal mechanisms: validating deep representations for interventional robustness. In International conference on machine learning, pp. 6056–6065, PMLR, 2019.

[148] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, Intriguing properties of neural networks. 2013, arXiv:1312.6199.

[149] M. Tangemann, S. Schneider, J. von Kügelgen, F. Locatello, P. Gehler, T. Brox, M. Kümmerer, M. Bethge, and B. Schölkopf, Unsupervised object learning via common fate. 2021, arXiv:2110.06562.

[150] J. Tian and J. Pearl, Causal discovery from changes. In Proceedings of the seventeenth conference on uncertainty in artificial intelligence, pp. 512–521, Morgan Kaufmann Publishers Inc., 2001.

[151] A. Tsiaras, I. Waldmann, G. Tinetti, J. Tennyson, and S. Yurchenko, Water vapour in the atmosphere of the habitable-zone eight-earth-mass planet K2-18b. Nat. Astron. 3 (2019), 1086–1091.

[152] A. van den Oord, Y. Li, and O. Vinyals, Representation learning with contrastive predictive coding. 2018, arXiv:1807.03748.

[153] V. N. Vapnik, Statistical learning theory. Wiley, New York, NY, 1998.

[154] J. von Kügelgen, L. Gresele, and B. Schölkopf, Simpson' s paradox in Covid-19 case fatality rates: a mediation analysis of age-related causal effects. IEEE Trans. Artif. Intell. 2 (2021), no. 1, 18–27.

[155] J. von Kügelgen, A.-H. Karimi, U. Bhatt, I. Valera, A. Weller, and B. Schölkopf, On the fairness of causal algorithmic recourse. In 36th AAAI conference on artificial intelligence, AAAI Press, 2022.

[156] J. von Kügelgen, A. Mey, M. Loog, and B. Schölkopf, Semi-supervised learning, causality and the conditional cluster assumption. In Conference on uncertainty in artificial intelligence, pp. 1–10, AUAI Press, 2020.

[157] J. von Kügelgen, I. Ustyuzhaninov, P. Gehler, M. Bethge, and B. Schölkopf, Towards causal generative scene models via competition of experts. In ICLR 2020 workshop on causal learning for decision making, OpenReview.net, 2020.

[158] J. von Kügelgen, Y. Sharma, L. Gresele, W. Brendel, B. Schölkopf, M. Besserve, and F. Locatello, Self-supervised learning with data augmentations provably isolates content from style. In Advances in neural information processing systems 34, Curran Associates, Inc., 2021.

[159] J. Woodward. Causation and manipulability, Stanford Encyclopedia of Philosophy, 2001.

[160] P. G. Wright, Tariff on animal and vegetable oils. Macmillan Company, New York, 1928.

[161] S. Wright, Correlation and causation. J. Agric. Res. 20 (1921), 557–580.

[162] J. Zhang and E. Bareinboim, Fairness in decision-making –the causal explanation formula. In Proceedings of the thirty-second AAAI conference on artificial intelligence, pp. 2037–2045, AAAI Press, 2018.

[163] K. Zhang, M. Gong, and B. Schölkopf, Multi-source domain adaptation: a causal view. In Proceedings of the 29th AAAI conference on artificial intelligence, pp. 3150–3157, AAAI Press, 2015.

[164] K. Zhang and A. Hyvärinen, On the identifiability of the post-nonlinear causal model. In Proceedings of the 25th annual conference on uncertainty in artificial intelligence (UAI), pp. 647–655, AUAI Press, 2009.

[165] K. Zhang, J. Peters, D. Janzing, and B. Schölkopf, Kernel-based conditional independence test and application in causal discovery. In Proceedings of the 27th annual conference on uncertainty in artificial intelligence (UAI), pp. 804–813, AUAI Press, 2011.

[166] K. Zhang, B. Schölkopf, K. Muandet, and Z. Wang, Domain adaptation under target and conditional shift. In Proceedings of the 30th international conference on machine learning, pp. 819–827, PMLR, 2013.

作者信息

Bernhard Schölkopf：马克斯 · 普朗克智能系统研究所，德国蒂宾根；bs@tuebingen.mpg.de。

Julius von Kügelgen：马克斯 · 普朗克智能系统研究所，德国蒂宾根；英国剑桥大学，剑桥；jvk@tuebingen.mpg.de。