



神经网络的统计力学

Statistical Mechanics of Neural Networks

HAIPING HUANG

1st edition · Springer Nature Singapore /
Higher Education Press · 2021

Model: OpenAI Codex (GPT-5)

审核: 曹溪能

Updated: 29 Aug 2026

出版与版权信息

原著作者：黄海平，中山大学，广州，中国.

ISBN 978-981-16-7569-0; 电子书 ISBN 978-981-16-7570-6; DOI: <https://doi.org/10.1007/978-981-16-7570-6>.

本书与高等教育出版社联合出版. 印刷版不在中国大陆销售; 中国大陆读者请向高等教育出版社订购印刷版.

© 高等教育出版社 2021. 本作品受版权保护. 无论涉及作品整体还是部分内容, 所有权利均由出版者单独并专有地许可, 包括翻印、重复使用插图、朗诵、广播、缩微复制或以任何其他实体方式复制, 以及通过现有或未来开发的相同或不同方法进行传输、信息存储与检索、电子改编和计算机软件处理等权利.

本出版物中使用一般性描述名称、注册名称、商标和服务标志等, 即使未作特别声明, 也不意味着这些名称不受相关保护法律法规约束或可自由使用. 出版者、作者和编辑认为, 本书中的建议与信息在出版之日真实且准确; 但对于书中内容以及可能存在的错误或遗漏, 出版者、作者和编辑均不作任何明示或默示的保证. 对于地图中的司法管辖权主张和机构隶属关系, 出版者保持中立.

本 Springer 品牌由注册公司 Springer Nature Singapore Pte Ltd 出版. 注册地址: 152 Beach Road, #21-01/04 Gateway East, Singapore 189721, Singapore.

谨以此书献给我的妻子潘慧红，
以及我的孩子黄晴和黄云。

译本说明

本译本以 2021 年出版的英文 PDF 为公式、结构、编号和可见内容的最高依据. PDF 文本层、图像提取和逐页渲染仅作为录入草稿; 遇到冲突时一律回到出版 PDF. 原书中的疑似错误不作静默修正, 而在问题清单中记录. 行间公式、交叉引用、图表和参考文献按 MathTranslations 模板重排, 并分别进行中文与术语、数学与结构、构建与视觉三轮审校.

本译本由曹溪能审核.

审核: 曹溪能

29 Aug 2026

前言

神经网络已经成为科学研究和工业应用诸多领域中的强大工具。然而，人们仍不清楚这一工具的内部工作机制，这妨碍了我们深入理解它，也妨碍了以原理为指导进一步设计更强大的网络架构和优化算法。要破解这个黑箱，必须综合物理学、统计学、信息论、非凸优化等不同学科；这种综合也可能弥合人工神经网络与大脑之间的鸿沟。然而，在这一高度交叉的领域中，系统介绍理解神经网络所需理论物理基础、尤其覆盖神经网络近期前沿主题的专著仍然很少。

本书从物理学视角讨论神经网络理论，乃至大脑模型中的神经计算。内容涵盖统计力学、统计推断和神经网络的基础，尤其包括对不同性质神经网络的经典与近期平均场分析。这些用统计力学分析神经网络的例子在数学上十分优美；我们期待它们启发新的技术，从而为更复杂的网络建立解析理论。本书也评述了科学机器学习和脑计算理论模型等方向的重要未来课题。

需要说明的是，本书并非对人工神经网络和神经网络平均场理论两个领域的完整综述，而是从统计物理方法出发理解深度学习黑箱的一种有所侧重的观点，主要面向对神经网络学习的平均场理论感兴趣的初学者和研究人员。

本书源自一系列讨论统计力学与神经网络相互作用的讲座。2018 至 2020 年间，作者在其 PMI (physics, machine and intelligence, 物理、机器与智能) 研究组讲授了这些内容。全书分为两部分：与神经网络理论相关的统计力学基础，以及包括皮层模型在内的神经网络理论研究。

第一部分又分为九章。第 1 章简述神经网络研究史。第 2 章介绍多自旋相互作用模型以及用来计算无序系统配分函数的腔方法。第 3 章介绍包括 Bethe 近似和置信传播算法在内的变分平均场方法。第 4 章介绍用于获得统计力学系统低能构型的蒙特卡洛模拟方法。第 5 章介绍高温展开技术。第 6 章介绍发现 Nishimori 线的自旋玻璃模型。第 7 章介绍随机能量模型，它是多自旋无序系统的无穷体相互作用极限。第 8 章介绍 Hopfield 模型的统计力学理论；该模型依据 Hebb 局域学习规则设计，用于随机模式的联想记忆。第 9 章介绍无序系统自旋玻璃理论中的副本对称性和副本对称性破缺概念。

第二部分同样分为九章。第 10 章介绍玻尔兹曼机学习（在物理学中也称逆 Ising 问题，在统计学中也称最大熵方法）以及受限玻尔兹曼机学习的统计力学；本章还深入介绍学习具有离散突触的一般 RBM 的变分平均场理论。第 11 章介绍最简单的无监督学习模型。第 12 章讨论 RBM（只考虑两个隐藏神经元）无监督学习的本质：无监督学习过程可理解为一系列连续相变，其中既有权重反转对称性破缺，也有隐藏神经元置换对称性破缺。第 13 章介绍单层离散感知机及其平均场理论。第 14 章介绍多层感知机的平均场模型及其腔方法分析，还介绍具有离散突触的多层感知机平均场训练算法，以及从系综视角出发的平均场训练。第 15 章介绍深度随机神经网络中降维的平均场理论。第 16 章介绍随机循环神经网络的混沌理论，包括皮层回路的兴奋-抑制平衡理论，以及训练一般 RNN 的时间反向传播。第 17 章介绍如何用统计力学技术计算 Hermitian 与非 Hermitian 随机矩阵谱密度的渐近行为。最后，本书展望了面向深度学习的统计力学理论以及智能的其他有趣方面，希望由此启发物理学、机器学习、理论神经科学及其他相关学科交叉领域的未来发展。

感谢各位学生为讲义初稿和插图准备所付出的努力。PMI 组学生的章节贡献如下：

黄振业 (第 4、10 章)、姜子健 (第 2、13、16 章)、李婵 (第 11、15、16 章)、周建文 (第 5、8、17 章)、邹文轩 (第 3、6、14 章) 和侯天琦 (第 12 章). 也感谢 PMI 组其他成员陈梓铭、焦一鸣、邱俊斌、谢明山、徐贤博和赵阳对初稿提出的阅读反馈. 还要感谢周海军、K. Y. Michael Wong、Yoshiyuki Kabashima 和 Taro Toyozumi 在作者攻读博士学位和从事博士后研究期间给予的鼓励与支持. 最后, 感谢国家自然科学基金 (项目号 11805284、12122515) 的资助.

黄海平
中国广州
2021 年 12 月

作者简介

黄海平博士在中国科学院理论物理研究所获得理论物理博士学位，现任中山大学物理学院副教授。他的研究兴趣包括二值感知机模型计算困难的起源、深度神经网络中的降维理论，以及无监督学习中的内禀对称性破缺。2021 年，他获得国家自然科学基金优秀青年科学基金资助。

缩略语

缩写	含义
AMP	近似消息传递 (approximate message passing)
AT	de Almeida–Thouless
BA	Bethe 近似 (Bethe approximation)
BM	玻尔兹曼机 (Boltzmann machine)
BP	置信传播 (belief propagation)
BPTT	时间反向传播 (backpropagation through time)
CD	对比散度 (contrastive divergence)
CLT	中心极限定理 (central limit theorem)
CNN	卷积神经网络 (convolution neural network)
DG	二分 Gaussian (dichotomized Gaussian)
EA	Edwards–Anderson
EM	期望最大化 (expectation maximization)
gBP	广义反向传播 (generalized backpropagation)
KL	Kullback–Leibler
LIF	漏积分发放 (leaky-integrated firing)
LSTM	长短期记忆 (long short-term memory)
MCMC	Markov 链蒙特卡洛 (Markov chain Monte Carlo)
MCS	蒙特卡洛扫描 (Monte Carlo sweep)
MFA	平均场近似 (mean-field approximation)
MPM	后验边缘最大化量 (maximizer of the posterior marginal)
PS	置换对称性 (permutation symmetry)
PSB	置换对称性破缺 (permutation symmetry breaking)
RAP	随机活跃路径 (random active path)
RBM	受限玻尔兹曼机 (restricted Boltzmann machine)
RF	感受野 (receptive field)
RG	随机猜测 (random guess)
RNN	循环神经网络 (recurrent neural network)
RS	副本对称性 (replica symmetry)
RSB	副本对称性破缺 (replica symmetry breaking)
SaS	尖峰–厚尾 (spike and slab)
SDE	鞍点方程 (saddle-point equation)
SG	自旋玻璃 (spin glass)
SK	Sherrington–Kirkpatrick
sMP	简化消息传递 (simplified message passing)
SSB	自发对称性破缺 (spontaneous symmetry breaking)
TAP	Thouless–Anderson–Palmer

目录

出版与版权信息	i
译本说明	iii
前言	iv
作者简介	vi
缩略语	vii
第 1 章 引言	1
第 1 章参考文献	2
第 2 章 自旋玻璃模型与腔方法	5
2.1 多自旋相互作用模型	5
2.2 腔方法	7
2.3 从腔方法到消息传递算法	10
第 2 章参考文献	12
第 3 章 变分平均场理论与置信传播	13
3.1 变分方法	13
3.2 变分自由能	14
3.2.1 平均场近似	15
3.2.2 Bethe 近似	16
3.2.3 从 Bethe 近似到朴素平均场近似	21
3.3 平均场逆 Ising 问题	22
第 3 章参考文献	23
第 4 章 Monte Carlo 模拟方法	24
4.1 Monte Carlo 方法	24
4.2 重要性抽样	25
4.3 Markov 链抽样	25
4.4 统计物理中的 Monte Carlo 模拟	26
4.4.1 Metropolis 算法	26
4.4.2 并行回火 Monte Carlo	28
第 4 章参考文献	30
第 5 章 高温展开	31
5.1 统计物理设定	31
5.2 高温展开	33
5.3 TAP 方程的性质	36
第 5 章参考文献	37
第 6 章 Nishimori 线	38
6.1 模型设定	38

6.2	内能的精确结果	38
6.3	Nishimori 线上无 RSB 效应的证明	39
	第 6 章参考文献	40
第 7 章	随机能量模型	41
7.1	模型设定	41
7.2	相图	42
	第 7 章参考文献	43
第 8 章	Hopfield 模型的统计力学理论	44
8.1	Hopfield 模型	44
8.2	复制方法	46
8.2.1	复制对称设定	51
8.2.2	零温极限	53
8.3	相图	54
8.4	任意 Hebb 长度的 Hopfield 模型	55
8.4.1	无序平均自由能的计算	56
8.4.2	鞍点方程的推导	61
8.4.3	求解鞍点方程的计算变换	62
8.4.4	零温极限	63
	第 8 章参考文献	66
第 9 章	复制对称与复制对称破缺	68
9.1	广义自由能与态复杂度	68
9.2	在约束满足问题中的应用	70
9.3	更多步复制对称破缺	72
	第 9 章参考文献	73
第 10 章	受限 Boltzmann 机的统计力学	76
10.1	Boltzmann 机	76
10.2	受限 Boltzmann 机	77
10.3	自由能计算	79
10.4	与学习有关的热力学量	80
10.5	稳定性分析	83
10.6	训练二元 RBM 的变分平均场理论	85
10.6.1	二元权重 RBM	85
10.6.2	变分原理	85
10.6.3	实验	88
第 11 章	二元突触无监督学习的最简模型	92
11.1	模型设定	92
11.2	sMP 与 AMP 方程的推导	94
11.3	副本计算	95
11.3.1	$[Z^n]$ 的显式形式	96

11.3.2	副本对称设定下的估计	96
11.3.3	自由能与鞍点方程	98
11.4	相变	99
11.5	测量数据集温度	100
第 12 章	无监督学习中的内禀对称破缺	105
12.1	模型设定	105
12.1.1	腔近似	106
12.1.2	副本计算	110
12.1.3	稳定性分析	122
12.2	相图	126
12.3	超参数推断	128
第 13 章	Ising 感知机的平均场理论	132
13.1	Ising 感知机模型	132
13.2	基于消息传递的学习	133
13.3	副本分析	135
13.3.1	副本对称	136
13.3.2	副本对称破缺	138
13.4	理论的进一步发展	140
第 14 章	多层感知机的平均场模型	144
14.1	随机活跃路径模型	144
14.1.1	腔方法的结果	146
14.1.2	无限深度分析	146
14.2	平均场训练算法	149
14.3	尖峰-平板模型	150
14.3.1	系综视角	150
14.3.2	训练方程	151
第 15 章	降维的平均场理论	154
15.1	平均场模型	154
15.2	线性维数与相关强度	156
15.2.1	相关强度的迭代方程	156
15.2.2	降维机制	157
15.3	相关突触下的降维	159
15.3.1	模型设定	159
15.3.2	平均场计算	160
15.3.3	数值结果与理论比较	164
第 16 章	随机循环神经网络的混沌理论	168
16.1	脉冲模型与发放率模型	168
16.2	动力学平均场理论	170
16.2.1	动力学平均场方程	170

16.2.2	网络动力学区间	171
16.3	Lyapunov 指数与混沌	173
16.4	兴奋-抑制平衡理论	174
16.5	循环神经网络的训练	175
16.5.1	FORCE 训练	175
16.5.2	时间反向传播	176
第 17 章	随机矩阵的统计力学	182
17.1	谱密度	182
17.2	副本法与半圆律	183
17.3	腔方法与 Marchenko–Pastur 律	185
17.4	随机非对称矩阵的谱密度	188
第 18 章	展望	193
	术语索引	198

引言

神经网络研究源于人们对大脑如何工作、乃至高级智能的生物机制的好奇 [1]. 这种最初的好奇心由来已久，其历史也正是人类努力理解大脑的历史. 1943 年，McCulloch 和 Pitts 提出现代人工神经元模型 [2]，把具有复杂生物过程的神经元抽象为输入简单加权和非线性传递函数. 数年后，Donald Hebb 提出 Hebb 学习规则 (Hebbian learning rule) [3]，即“共同发放的细胞会连接在一起”. 这一规则奠定了后来发展的基础：在所谓 Hopfield 模型 [4, 5] 这一联想记忆抽象模型中，Hebb 规则用来构造神经元之间的有效耦合；从某个记忆项只有少数比特受损的初态出发，在噪声较弱的神经动力学下，模型可以恢复该记忆项（例如 Hebb 规则所用的一个随机模式）. Hebb 规则虽很简单，却在当今实验神经科学与理论神经科学研究中都发挥着极其重要的作用 [6].

以 McCulloch–Pitts 人工神经元模型为基础，Frank Rosenblatt 针对监督分类任务提出了第一个感知机 (perceptron) 模型 [7]. 当时，这一模型只能对线性可分模式进行分类 [8]. 不过，这一抽象模型在神经科学研究中十分重要，因为感知机模型被广泛用于刻画小脑 Purkinje 细胞的学习行为 [9, 10]. 感知机也很容易推广到多层前馈神经网络；由于逐层计算具有高度嵌套的非线性，这种网络能够分离非线性可分的模式. 但这种嵌套非线性也使学界很难从解析上理解其内部工作机制 [11, 12]. 尽管如此，从高层向下传播误差已被证明能用于多层神经网络的实际训练 [13]，由此奠定了深度学习的算法基础.

1980 年，Fukushima 借鉴在猫视觉皮层通路中观察到的简单细胞与复杂细胞这一生物学概念，提出了神经认知机 [14]. 当这些神经计算以层级方式组织起来时，便可实现位置平移不变性. 神经认知机启发了多层神经计算的进一步发展，例如 20 世纪 90 年代提出的强大架构——卷积神经网络 (convolution neural network, CNN) [15]. 在 CNN 中，简单细胞的计算对应卷积，复杂细胞的计算对应池化，展示了多层神经网络在解决计算机视觉等实际任务中的能力 [16].

1985 年，Hinton 和 Sejnowski 提出玻尔兹曼机 (Boltzmann machine) [17]. 在这一模型中，可直接从数据样本学习 Ising 模型的耦合、场等参数，而只需匹配数据统计量的前两个矩 [18]. 近年来，这一框架在系统神经科学中重新受到关注 [19]；在物理学中它称为逆 Ising 问题 [20]，并广泛应用于从神经活动建模、蛋白质结构预测到金融数据分析等不同交叉领域 [21]. 随后，Paul Smolensky 提出最初的随机激活双层神经网络 [22]，即受限玻尔兹曼机 (restricted Boltzmann machine, RBM) [22, 23]. 其中，传统玻尔兹曼机中的神经元被分为可见组和隐藏组. 2006 年，Hinton 和 Salakhutdinov 提出高效方法，用逐层堆叠的 RBM 训练深度置信网络 [24]，开启了学术界和工业界的深度学习革命.

另一类神经网络架构的显著特点是引入时间信息的循环计算. 1990 年前后，人们对相关算法问题进行了大量研究 [25, 26, 27, 28]. 然而，由于目标函数存在梯度消失

或爆炸问题，循环神经网络（recurrent neural network, RNN）通常很难训练 [29]。在当今深度学习时代，人们提出了许多巧妙技术来应对这一挑战。特别是 Hochreiter 和 Schmidhuber 引入了采用多种信息门控机制的长短期记忆（long short-term memory, LSTM）[30]，以规避 RNN 的训练困难。RNN 结构也被视为感知、学习、记忆、行动及其他高级认知过程的典范模型 [31, 32, 33]。

在人工神经网络的发展史中，上述回顾仍未涵盖许多重要主题。对此感兴趣的读者可参阅近期的若干神经网络综述 [34, 35, 36]。另一方面，统计力学在理解人工神经网络、甚至真实神经元网络的涌现行为方面发挥着关键作用 [37]。

神经网络的第一个统计力学理论发表于 1985 年；它给出了 Hopfield 网络的完整相图 [38, 39]，并说明要从嵌入的随机模式（类似记忆项）中成功恢复一个模式，低温和低记忆负载是必要条件。相关解析技术源于对自旋玻璃等无序系统的研究 [40, 41]。一项强有力的技术是副本技巧（replica trick）：它引入原模型的许多副本，把原先复杂的自旋间相互作用解耦为副本之间的重叠，而这些重叠恰好就是统计力学模型的序参量。此后，这项技术推广到感知机模型，并引入 Gardner 体积这一概念，以确定感知机系统的容量 [42, 43]。Gardner 方法至今仍是理论神经科学界常用的强大物理工具 [10]。

1988 年，Sompolinsky 等人发展了另一种强有力的物理方法，用于分析具有随机权重的 RNN 的循环动力学 [44]。该方法把真实 RNN 的行为视为均匀系统的一个有效平均场极限，递归建立神经动力学统计量的前两个矩，从而以平均场方法计算 Lyapunov 指数，并据此判断是否可能发生向混沌态的转变。这一框架可在动力学的路径积分表示下导出 [45, 46]，至今仍常用于分析具有结构化连接的更复杂 RNN。后来，随机 RNN 的平均场研究被推广到由兴奋性和抑制性细胞组成的神经元网络 [47, 48]；这类网络满足生物学上的 Dale 规则，即一个生物神经元不能同时产生兴奋性突触和抑制性突触。在该研究中，可以在平均场极限下识别出兴奋-抑制平衡条件 [49, 50]，也就是反馈抑制抵消强烈的兴奋性循环输入。这为皮层回路中观察到的不规则异步神经活动给出了机制解释。Brunel 进一步研究了稀疏连接的兴奋-抑制神经网络中脉冲活动的涌现行为 [51]。即使在今天，这些理论范式仍使计算与理论研究界受益。因此，包括平衡态相图分析和非平衡平均场理论在内的统计物理方法，很有希望用于探索深度神经网络的黑箱；它们还可能进一步联系到随机矩阵理论等其他分支 [52]。

本书将介绍我们个人选取的、应用于神经网络研究的统计力学技术，并深入阐述这些统计物理方法，尤其关注简单玩具模型中的应用；在这些模型里，学习机制可以用数学上简洁的方式揭示，甚至还能对新的涌现行为作出理论预言。

参考文献

- [1] R. Yuste, Nat. Rev. Neurosci. 16(8), 487 (2015).
- [2] W. S. McCulloch and W. Pitts, Bull. Math. Biophys. 5, 115 (1943).
- [3] D. O. Hebb, *The Organization of Behavior* (Wiley, New York, 1949).
- [4] J. J. Hopfield, Proc. Natl. Acad. Sci. USA 79, 2554 (1982).
- [5] S. I. Amari, Biological Cybern. 26, 175 (1977).

- [6] W. Gerstner et al., *Front. Neural Circ.* 12, 53 (2018).
- [7] F. Rosenblatt, *Psychol. Rev.* 65, 386 (1958).
- [8] S. Papert and M. L. Minsky, *Perceptrons* (MIT Press, Cambridge, 1988).
- [9] C. Clopath, J. P. Nadal, and N. Brunel, *PLOS Comput. Biol.* 8(4), e1002448 (2012).
- [10] N. Brunel, *Nat. Neurosci.* 19, 749 (2016).
- [11] A. Saxe, S. Nelli, and C. Summerfield, *Nat. Rev. Neurosci.* 22, 55 (2020).
- [12] D. Hassabis et al., *Neuron* 95(2), 245 (2017).
- [13] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, *Nature* 323, 533 (1986).
- [14] K. Fukushima, *Biolog. Cybern.* 36(4), 193 (1980).
- [15] Y. LeCun et al., *Proc. IEEE* 86, 2278 (1998).
- [16] A. Krizhevsky, I. Sutskever, and G. E. Hinton, *Advances in Neural Information Processing Systems 25*, 1097–1105 (2012).
- [17] D. H. Ackley, G. E. Hinton, and T. J. Sejnowski, *Cognit. Sci.* 9(1), 147 (1985).
- [18] E. T. Jaynes, *Phys. Rev.* 106, 620 (1957).
- [19] E. Schneidman et al., *Nature* 440, 1007 (2006).
- [20] Y. Roudi, E. Aurell, and J. Hertz, *Front. Comput. Neurosci.* 3, 1 (2009).
- [21] H. C. Nguyen, R. Zecchina, and J. Berg, *Adv. Phys.* 66(3), 197 (2017).
- [22] P. Smolensky, *Information Processing in Dynamical Systems*, 194–281 (MIT Press, Cambridge, 1986).
- [23] Y. Freund and D. Haussler, Technical Report, Santa Cruz, CA (1994).
- [24] G. Hinton and R. Salakhutdinov, *Science* 313, 504 (2006).
- [25] J. L. Elman, *Cognit. Sci.* 14(2), 179 (1990).
- [26] P. J. Werbos, *Neural Netw.* 1(4), 339 (1988).
- [27] F. J. Pineda, *Phys. Rev. Lett.* 59(19), 2229 (1987).
- [28] R. J. Williams and J. Peng, *Neural Comput.* 2(4), 490 (1990).
- [29] R. Pascanu, T. Mikolov, and Y. Bengio, *Proc. ICML*, 1310–1318 (2013).
- [30] S. Hochreiter and J. Schmidhuber, *Neural Comput.* 9(8), 1735 (1997).

- [31] D. Sussillo and L. Abbott, *Neuron* 63(4), 544 (2009).
- [32] D. V. Buonomano and W. Maass, *Nat. Rev. Neurosci.* 10(2), 113 (2009).
- [33] S. Vyas et al., *Ann. Rev. Neurosci.* 43(1), 249 (2020).
- [34] J. Schmidhuber, *Neural Netw.* 61, 85 (2015).
- [35] Y. LeCun, Y. Bengio, and G. Hinton, *Nature* 521(7553), 436 (2015).
- [36] P. Mehta et al., *Phys. Rep.* 810, 1 (2019).
- [37] D. J. Amit, *Modeling Brain Function* (Cambridge University Press, Cambridge, 1989).
- [38] D. J. Amit, H. Gutfreund, and H. Sompolinsky, *Phys. Rev. A* 32, 1007 (1985).
- [39] D. J. Amit, H. Gutfreund, and H. Sompolinsky, *Phys. Rev. Lett.* 55(14), 1530 (1985).
- [40] M. Mézard, G. Parisi, and M. A. Virasoro, *Spin Glass Theory and Beyond* (World Scientific, Singapore, 1987).
- [41] P. Peretto, *Biolog. Cybern.* 50(1), 51 (1984).
- [42] E. Gardner, *Europhys. Lett.* 4, 481 (1987).
- [43] E. Gardner, *J. Phys. A* 21, 257 (1988).
- [44] H. Sompolinsky, A. Crisanti, and H. J. Sommers, *Phys. Rev. Lett.* 61(3), 259 (1988).
- [45] A. Crisanti and H. Sompolinsky, *Phys. Rev. E* 98(6), 062120 (2018).
- [46] M. Helias and D. Dahmen, arXiv:1901.10416 (2019).
- [47] C. van Vreeswijk and H. Sompolinsky, *Science* 274(5293), 1724 (1996).
- [48] C. van Vreeswijk and H. Sompolinsky, *Neural Comput.* 10(6), 1321 (1998).
- [49] M. N. Shadlen and W. T. Newsome, *J. Neurosci.* 18(10), 3870 (1998).
- [50] M. Okun and I. Lampl, *Nat. Neurosci.* 11(5), 535 (2008).
- [51] N. Brunel, *J. Comput. Neurosci.* 8(3), 183 (2000).
- [52] M. L. Mehta, *Random Matrices* (Academic, San Diego, 2004).

自旋玻璃模型与腔方法

自旋玻璃 (spin glass) 是一类二自旋相互作用具有随机符号的磁体 [1], 例如磁矩随机分布的合金. 在自旋玻璃模型中, 随机性出现在自旋相互作用里. 例如, 在 Sherrington–Kirkpatrick 模型 [2] 中, 所有二自旋相互作用都独立服从方差为 $N^{-1/2}$ 的 Gaussian 分布 (N 为系统大小); 在 Edwards–Anderson 模型 [3] 中, 自旋位于有限维晶格上; 在 Bethe 晶格模型 [4, 5] 中, 每个自旋位于具有有限连接度的随机晶格上. 这些模型都属于多自旋相互作用模型: 它们最初在物理学中研究, 后来又在计算机科学、机器学习和计算神经科学的优化问题背景下得到广泛探索.

2.1 多自旋相互作用模型

在深入讨论其物理机制之前, 先给出自旋玻璃模型的几个开创性应用. 第一个是随机 K -SAT 问题. 随机 K -SAT 要为 N 个 Boolean 变量找到一个赋值, 使由 M 个子句的逻辑 AND 所组成的随机公式为真. 每个子句是从变量集合中随机选取的 K 个不同变量的逻辑 OR; 每个变量以相同概率取原变量或其否定. 例如

$$\mathcal{F} = (\bar{x}_3 \vee x_7 \vee \bar{x}_2) \wedge (\bar{x}_1 \vee x_5 \vee \bar{x}_6) \wedge (\bar{x}_4 \vee x_7 \vee \bar{x}_5). \quad (2.1)$$

从物理学视角看, 随机 K -SAT 可视为关注典型情形分析的自旋玻璃问题¹. 若 x_i 为 TRUE, 就把它映射为取值 1 (自旋向上) 的 Ising 自旋; 否则映射为 -1 (自旋向下). 给定一个自旋构型, 可以把未满足子句的数目定义为统计物理中的能量函数 [6]:

$$E(\sigma) = \sum_{m=1}^M \prod_{j=1}^K \frac{1 + J_j^m \sigma_{i_j^m}}{2}. \quad (2.2)$$

这里, i_j^m 是第 m 个子句中出现的第 j 个变量. 当公式中的 Boolean 变量以否定形式出现时, 淬火无序量 $J_j^m = 1$, 否则 $J_j^m = -1$. 因而, 约束满足问题化为寻找能量函数极小值的物理问题.

类似地, 随机 K -XOR SAT 公式可写成

$$\mathcal{F} = \bigwedge_{m=1}^M \left[\left(\bigoplus_{j=1}^K x_{i_j^m} \right) \oplus y_m \right], \quad (2.3)$$

其中 $\oplus$ 表示逻辑 XOR 运算, y_m 是淬火随机 Boolean 值. 这一公式对应一个线性系统, 可用 Gaussian 消元法高效求解. 在物理学中, 耦合取 ± 1 的稀释 Ising p -自旋模型属于

¹计算复杂度是在最坏情形设定下定义的.

随机 K -XOR 问题. 与随机 K -SAT 类似, 相应能量函数为 [7]

$$E(\boldsymbol{\sigma}) = \sum_{m=1}^M \frac{1 - J_m \prod_{j=1}^K \sigma_{i_j^m}}{2}, \quad (2.4)$$

其中 J_m 是 Boolean 变量 y_m 的 Ising 映射.

上述两个约束满足问题在物理学中都属于多自旋相互作用模型. 物理学家关心 $N \rightarrow \infty$ 、 $M \rightarrow \infty$ 而比值 M/N 保持不变的平均场极限. 自旋变量之间的复杂相互作用有望产生丰富的相变. 下面说明如何用腔方法计算这类模型的自由能. 腔方法最初用于重现 Sherrington–Kirkpatrick 模型的副本结果 [8], 随后在神经网络研究中得到重新表述 [9], 最终又在 Bethe 晶格这一大类有限连接度玻璃模型上形成简洁的物理表述和系统的数学表述 [5]. 我们还将在一个多自旋相互作用模型中详细考察腔方法背后的核心物理假设; 上述两个模型可用类似方式处理.

多自旋相互作用模型也可在信息传输背景下定义. 考虑向接收者发送消息的情形; 消息在传输过程中可能受到信道噪声扰动. 接收者要从受扰消息中恢复原消息, 是一项高度非平凡的任务. 一种办法是在发送端为原消息引入冗余, 接收端便可利用冗余纠正一部分传输错误. 1948 年, Claude Shannon 证明: 当码率低于信道容量时, 可以实现无差错传输; 这为设计工程上实用的编码确立了基本界限 [10]. 人们为设计逼近 Shannon 界的编码付出了大量努力. Surlas 码是物理学中第一个这样的方案 [11], 它把纠错码与自旋玻璃模型联系起来.

Surlas 码的构造很容易理解. 假设有一个 N 比特二值原消息 $\boldsymbol{\xi} \in \{\pm 1\}^N$, 把它编码成 M 比特的传输消息 $\boldsymbol{J}^0 = \{J_1^0, J_2^0, \dots, J_M^0\}$. 第 a 个比特是从原消息中随机选出的子集 ∂a 内各比特之积:

$$J_a^0 = \prod_{i \in \partial a} \xi_i. \quad (2.5)$$

用 J_a 表示接收消息的第 a 个比特. 由于信道噪声可能翻转消息比特, 它未必等于传输消息中的相应比特. 假设每个传输比特都以相同概率 p 独立翻转, 则条件概率为

$$P(J_a | J_a^0) = p \delta(J_a + J_a^0) + (1 - p) \delta(J_a - J_a^0). \quad (2.6)$$

为了解码发送的消息, 把计算任务写成具有如下 Hamiltonian 的统计力学问题 [12]:

$$H(\boldsymbol{\sigma}) = - \sum_{a=1}^M J_a \prod_{i \in \partial a} \sigma_i, \quad (2.7)$$

其中 σ_i 是用来解码原消息 $\{\xi_i\}$ 的动力学二值自旋变量. 我们需要计算后验概率

$$P(\boldsymbol{\sigma} | \boldsymbol{J}) = \frac{\exp[-\beta H(\boldsymbol{\sigma})]}{Z}, \quad (2.8)$$

其中 β 为逆温, Z 为配分函数. 于是, 解码过程等价于寻找这一统计力学问题的基态. 当 $\prod_{i \in \partial a} \sigma_i = J_a$ 时, 模型能量取极小值. 按照正则系综理论, 解码过程的全部涌现性质都包含在配分函数中:

$$Z = \sum_{\{\sigma_i\}} \exp[-\beta H(\boldsymbol{\sigma})]. \quad (2.9)$$

2.2 腔方法

本节用腔近似计算配分函数. 直接计算式 (2.9) 需要对 2^N 项求和; 一旦 $N > 30$, 在计算上便不可行. 对稀疏连接的因子图模型, 腔方法可把计算代价降至 $O(N)$.

模型可表示成因子图 [13], 用来说明自旋彼此如何相互作用, 见图 2.1. 我们要分析 Boltzmann 分布, 即式 (2.8) 的后验分布, 因此采用概率语言, 并以计算边缘概率为目标. 为此, 需要修改允许变量间存在强关联的原图. 若在原系统中加入函数节点 a , 见图 2.2, 新系统的 Hamiltonian 为

$$H^{\text{new}} = H^{\text{old}} - J_a \prod_{i \in \partial a} \sigma_i. \quad (2.10)$$

It then proceeds that




Fig. 2.1 Factor graph representation of a random construction of the Sourlas codes. Circles are

图 2.1: Sourlas 码随机构造的因子图表示. 圆表示自旋变量 (变量节点) $\{\sigma_i\}$, 方块表示接收消息 (函数节点) $\{J_a\}$. 图中只画出三个消息比特, 每个方块都与它们相连; 实际上方块还可与未画出的其他消息比特相连, 从而形成稀疏随机图, 变量节点的度服从 Poisson 分布.

$$\begin{aligned} Z^{\text{new}} &= \sum_{\{\sigma_i\}_{i=1}^N} \exp \left[-\beta H^{\text{old}} + \beta J_a \prod_{i \in \partial a} \sigma_i \right] \\ &= Z^{\text{old}} \sum_{\{\sigma_i\}_{i=1}^N} \frac{\exp(-\beta H^{\text{old}})}{Z^{\text{old}}} \exp \left(\beta J_a \prod_{i \in \partial a} \sigma_i \right). \end{aligned} \quad (2.11)$$

这里 $\exp(-\beta H^{\text{old}})/Z^{\text{old}}$ 正是旧系统中 $\{\sigma_i\}_{i=1}^N$ 的联合概率分布, 而最后一个指数因子只与 $\{\sigma_i \mid i \in \partial a\}$ 有关. 因而可把构型求和分为与新增节点直接相连的变量和其余变量两




Fig. 2.2 Addition of the function node a to original system (outside the shadow part). We call the

图 2.2: 在原系统中加入函数节点 (a) (阴影区域之外). 阴影区域称为腔, 节点 $\{i, j, k, l\}$ 构成腔边界.

部分:

$$\begin{aligned}
 Z^{\text{new}} &= Z^{\text{old}} \sum_{\{\sigma_i | i \in \partial a\}} \sum_{\{\sigma_i | i \notin \partial a\}} \frac{\exp(-\beta H^{\text{old}})}{Z^{\text{old}}} \exp\left(\beta J_a \prod_{i \in \partial a} \sigma_i\right) \\
 &= Z^{\text{old}} \sum_{\{\sigma_i | i \in \partial a\}} \exp\left(\beta J_a \prod_{i \in \partial a} \sigma_i\right) \sum_{\{\sigma_i | i \notin \partial a\}} \frac{\exp(-\beta H^{\text{old}})}{Z^{\text{old}}}. \quad (2.12)
 \end{aligned}$$

式 (2.12) 最后的求和正是旧系统中边界变量的边缘概率. 与新系统相比, 旧系统在加入函数节点 a 的位置有一个腔. 把边缘概率记作 $P_{\text{cavity}}(\{\sigma_i | i \in \partial a\})$, 并称 $\{\sigma_i | i \in \partial a\}$ 为腔边界. 对全连接系统, 边界变量间耦合很弱; 对稀疏模型, 拓扑是稀疏的, 因此假设边界变量弱相关是合理的. 若底层因子图为树, 这一假设严格成立. 所以

$$P_{\text{cavity}}(\{\sigma_i | i \in \partial a\}) \simeq \prod_{i \in \partial a} q_{i \rightarrow a}(\sigma_i), \quad (2.13)$$

其中 $q_{i \rightarrow a}$ 表示移去函数节点 a 时 σ_i 的分布. 定义腔磁化强度 $m_{i \rightarrow a} \equiv q_{i \rightarrow a}(+1) - q_{i \rightarrow a}(-1)$, 则 $q_{i \rightarrow a}(\sigma_i) = (1 + \sigma_i m_{i \rightarrow a})/2$. 因此

$$\begin{aligned}
 Z^{\text{new}} &= Z^{\text{old}} \sum_{\{\sigma_i | i \in \partial a\}} \exp\left(\beta J_a \prod_{i \in \partial a} \sigma_i\right) \prod_{i \in \partial a} \frac{1 + \sigma_i m_{i \rightarrow a}}{2} \\
 &= Z^{\text{old}} \cosh(\beta J_a) \left[1 + \tanh(\beta J_a) \prod_{i \in \partial a} m_{i \rightarrow a} \right]. \quad (2.14)
 \end{aligned}$$

由 $F = -\beta^{-1} \ln Z$ ，加入函数节点 a 引起的自由能变化为

$$-\beta \Delta F_a = \ln \frac{Z^{\text{new}}}{Z^{\text{old}}} = \ln \left\{ \cosh(\beta J_a) \left[1 + \tanh(\beta J_a) \prod_{i \in \partial a} m_{i \rightarrow a} \right] \right\}. \quad (2.15)$$

类似地，若加入变量节点 i 及其相邻函数节点 $\{b \mid b \in \partial i\}$ ，见图 2.3²，新系统的配分函数为

$$\begin{aligned} Z^{\text{new}} &= \sum_{\sigma^{\text{old}}} \sum_{\sigma_i} \exp \left[-\beta H^{\text{old}} + \beta \sum_{b \in \partial i} J_b \prod_{j \in \partial b} \sigma_j \right] \\ &= \sum_{\sigma^{\text{old}}} \sum_{\sigma_i} \exp \left[-\beta H^{\text{old}} + \beta \sum_{b \in \partial i} J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j \right] \\ &= Z^{\text{old}} \sum_{\sigma^{\text{old}}} \sum_{\sigma_i} \frac{\exp(-\beta H^{\text{old}})}{Z^{\text{old}}} \exp \left(\beta \sum_{b \in \partial i} J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j \right). \end{aligned} \quad (2.16)$$

这里， $j \in \partial b \setminus i$ 表示与函数节点 b 相连但不包括 i 的变量节点。集合 $\{\sigma_j \mid j \in \partial b \setminus i, b \in \partial i\}$ 构成腔边界。先对不在腔边界上的变量节点构型求和，再用式 (2.13)，得到

2.2 Cavity Method

11




Fig. 2.3 Adding a variable node i together with its neighboring function nodes $\{a, b, c\}$ to the

图 2.3: 在原系统中加入变量节点 (i) 及其相邻函数节点 $\{a, b, c\}$ (腔之外)。子集 $\{j, k, l, m, n, \dots\}$ 构成腔边界。

²这一操作使腔概率的定义变得合理。

$$\begin{aligned}
Z^{\text{new}} &= Z^{\text{old}} \sum_{\{\sigma_j | j \in \partial b \setminus i, b \in \partial i\}} \sum_{\sigma_i} P_{\text{cavity}}(\{\sigma_j | j \in \partial b \setminus i, b \in \partial i\}) \exp \left(\sum_{b \in \partial i} \beta J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j \right) \\
&\simeq Z^{\text{old}} \sum_{\{\sigma_j | j \in \partial b \setminus i, b \in \partial i\}} \sum_{\sigma_i} \prod_{b \in \partial i} \prod_{j \in \partial b \setminus i} q_{j \rightarrow b}(\sigma_j) \exp \left(\sum_{b \in \partial i} \beta J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j \right) \\
&= Z^{\text{old}} \sum_{\sigma_i} \prod_{b \in \partial i} \sum_{\{\sigma_j | j \in \partial b \setminus i\}} \prod_{j \in \partial b \setminus i} \frac{1 + \sigma_j m_{j \rightarrow b}}{2} \exp \left(\beta J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j \right) \\
&= Z^{\text{old}} \left(\prod_{b \in \partial i} \Lambda_{b \rightarrow i}^+ + \prod_{b \in \partial i} \Lambda_{b \rightarrow i}^- \right). \tag{2.17}
\end{aligned}$$

其中

$$\begin{aligned}
\Lambda_{b \rightarrow i}^+ &= \sum_{\{\sigma_j | j \in \partial b \setminus i\}} \prod_{j \in \partial b \setminus i} \frac{1 + \sigma_j m_{j \rightarrow b}}{2} \exp \left(\beta J_b (+1) \prod_{j \in \partial b \setminus i} \sigma_j \right) \\
&= \cosh(\beta J_b) \left[1 + \tanh(\beta J_b) \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right], \tag{2.18}
\end{aligned}$$

$$\begin{aligned}
\Lambda_{b \rightarrow i}^- &= \sum_{\{\sigma_j | j \in \partial b \setminus i\}} \prod_{j \in \partial b \setminus i} \frac{1 + \sigma_j m_{j \rightarrow b}}{2} \exp \left(\beta J_b (-1) \prod_{j \in \partial b \setminus i} \sigma_j \right) \\
&= \cosh(\beta J_b) \left[1 - \tanh(\beta J_b) \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right]. \tag{2.19}
\end{aligned}$$

所以，加入变量节点 i 及其相邻函数节点所引起的自由能变化为

$$-\beta \Delta F_i = \ln \frac{Z^{\text{new}}}{Z^{\text{old}}} = \ln \left(\prod_{b \in \partial i} \Lambda_{b \rightarrow i}^+ + \prod_{b \in \partial i} \Lambda_{b \rightarrow i}^- \right). \tag{2.20}$$

最终，总自由能为

$$F = \sum_i \Delta F_i + \sum_a \Delta F_a - \sum_a |\partial a| \Delta F_a. \tag{2.21}$$

其中 $|\partial a|$ 是与函数节点 a 相连的变量节点数。最后一项保证每个节点对总自由能的贡献只计数一次。一旦得到 $\{m_{j \rightarrow b}\}$ ，就可以计算自由能。下一节说明如何计算 $\{m_{i \rightarrow a}\}$ 。

2.3 从腔方法到消息传递算法

按照腔假设，由于随机因子图的局域结构在统计上是均匀的，腔磁化强度 $\{m_{i \rightarrow a}\}$ 可以迭代构造。 $m_{i \rightarrow a}$ 是去掉函数节点 a 的贡献后 σ_i 的期望值，因此

$$m_{i \rightarrow a} = \frac{\sum_{\boldsymbol{\sigma}} \sigma_i \exp[-\beta H_{i \rightarrow a}(\boldsymbol{\sigma})]}{\sum_{\boldsymbol{\sigma}} \exp[-\beta H_{i \rightarrow a}(\boldsymbol{\sigma})]}, \tag{2.22}$$

其中

$$H_{i \rightarrow a} = H_{\text{cavity}} - \sum_{b \in \partial i \setminus a} J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j. \quad (2.23)$$

H_{cavity} 是腔系统的 Hamiltonian; 该腔系统由原系统移去变量节点 i 及其相邻函数节点 $b \in \partial i$ (但 a 除外) 而得.

与第 2.2 节类似, 先对不在腔边界上的变量节点构型求和, 得到边界节点的边缘分布:

$$\begin{aligned} m_{i \rightarrow a} &= \frac{\sum_{\sigma} \sigma_i \exp[-\beta H_{i \rightarrow a}(\sigma)] / Z_{\text{cavity}}}{\sum_{\sigma} \exp[-\beta H_{i \rightarrow a}(\sigma)] / Z_{\text{cavity}}} \\ &= \frac{\sum_{\sigma_i} \sum_{\mathcal{B}} \sigma_i P_{\text{cavity}}(\mathcal{B}) \exp\left(\sum_{b \in \partial i \setminus a} \beta J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j\right)}{\sum_{\sigma_i} \sum_{\mathcal{B}} P_{\text{cavity}}(\mathcal{B}) \exp\left(\sum_{b \in \partial i \setminus a} \beta J_b \sigma_i \prod_{j \in \partial b \setminus i} \sigma_j\right)}. \end{aligned} \quad (2.24)$$

其中 Z_{cavity} 对应 H_{cavity} , 而 $\mathcal{B} \equiv \{\sigma_j \mid j \in \partial b \setminus i; b \in \partial i \setminus a\}$ 表示腔边界. 腔近似给出

$$P_{\text{cavity}}(\mathcal{B}) \simeq \prod_{b \in \partial i \setminus a} \prod_{j \in \partial b \setminus i} q_{j \rightarrow b}(\sigma_j). \quad (2.25)$$

采用与式 (2.17) 相同的技术, 得到

$$m_{i \rightarrow a} = \frac{\prod_{b \in \partial i \setminus a} \Lambda_{b \rightarrow i}^+ - \prod_{b \in \partial i \setminus a} \Lambda_{b \rightarrow i}^-}{\prod_{b \in \partial i \setminus a} \Lambda_{b \rightarrow i}^+ + \prod_{b \in \partial i \setminus a} \Lambda_{b \rightarrow i}^-}. \quad (2.26)$$

定义共轭腔磁化强度

$$\hat{m}_{b \rightarrow i} \equiv \tanh(\beta J_b) \prod_{j \in \partial b \setminus i} m_{j \rightarrow b}, \quad (2.27)$$

则

$$m_{i \rightarrow a} = \frac{\prod_{b \in \partial i \setminus a} (1 + \hat{m}_{b \rightarrow i}) - \prod_{b \in \partial i \setminus a} (1 - \hat{m}_{b \rightarrow i})}{\prod_{b \in \partial i \setminus a} (1 + \hat{m}_{b \rightarrow i}) + \prod_{b \in \partial i \setminus a} (1 - \hat{m}_{b \rightarrow i})}. \quad (2.28)$$

引入腔局域场 $h_{i \rightarrow a}$ 和腔偏置 $u_{a \rightarrow i}$ [5], 用它们参数化腔概率:

$$\begin{aligned} q_{i \rightarrow a}(\sigma_i) &\equiv \frac{\exp(\beta h_{i \rightarrow a} \sigma_i)}{2 \cosh(\beta h_{i \rightarrow a})}, \\ p_{a \rightarrow i}(\sigma_i) &\equiv \frac{\exp(\beta u_{a \rightarrow i} \sigma_i)}{2 \cosh(\beta u_{a \rightarrow i})}. \end{aligned} \quad (2.29)$$

其中 $p_{a \rightarrow i}(\sigma_i) = (1 + \sigma_i \hat{m}_{a \rightarrow i})/2$, 从而

$$\begin{aligned} m_{i \rightarrow a} &= \tanh(\beta h_{i \rightarrow a}), \\ \hat{m}_{a \rightarrow i} &= \tanh(\beta u_{a \rightarrow i}). \end{aligned} \quad (2.30)$$

于是式 (2.27)和式 (2.28)化为

$$\begin{aligned} h_{i \rightarrow a} &= \frac{1}{\beta} \sum_{b \in \partial i \setminus a} \beta u_{b \rightarrow i}, \\ u_{a \rightarrow i} &= \frac{1}{\beta} \tanh^{-1} \left[\tanh(\beta J_a) \prod_{j \in \partial a \setminus i} \tanh(\beta h_{j \rightarrow a}) \right]. \end{aligned} \quad (2.31)$$

这正是 Sourlas 码情形下的消息传递方程. 腔方法本质上是一种概率迭代方法: 迭代求解这些方程, 直至消息 $\{m_{i \rightarrow a}\}$ 达到不动点, 再计算完整磁化强度

$$m_i = \tanh \left(\sum_{b \in \partial i} \beta u_{b \rightarrow i} \right). \quad (2.32)$$

随后用后验边缘最大化量 (MPM) 解码, 即 $\sigma_i = \arg \max_{\sigma_i} P_i(\sigma_i)$, 其中 $P_i(\sigma_i) = (1 + \sigma_i m_i)/2$. 自由能和其他热力学量也可由上述公式计算. 对稀疏因子图, 复杂度为 $O(N)$; 若所有变量节点都与每个函数节点相连, 则为 $O(N^2)$. 这一过程相当一般, 可适配多种神经网络学习问题.

参考文献

- [1] M. Mézard, G. Parisi, and M. A. Virasoro, *Spin Glass Theory and Beyond* (World Scientific, Singapore, 1987).
- [2] D. Sherrington and S. Kirkpatrick, Phys. Rev. Lett. 35(26), 1792 (1975).
- [3] S. F. Edwards and P. W. Anderson, J. Phys. F: Metal Phys. 5(5), 965 (1975).
- [4] L. Viana and A. J. Bray, J. Phys. C 18(15), 3037 (1985).
- [5] M. Mézard and G. Parisi, Eur. Phys. J. B 20, 217 (2001).
- [6] M. Mézard and R. Zecchina, Phys. Rev. E 66(5), 056126 (2002).
- [7] S. Franz et al., Phys. Rev. Lett. 87(12), 127209 (2001).
- [8] M. Mézard, G. Parisi, and M. A. Virasoro, Europhys. Lett. 1(2), 77 (1986).
- [9] M. Mézard, J. Phys. A 22(12), 2181 (1989).
- [10] C. E. Shannon, Bell Syst. Tech. J. 27(3), 379 (1948).
- [11] N. Sourlas, Nature 339(6227), 693 (1989).
- [12] H. Huang and H. Zhou, Phys. Rev. E 80, 056113 (2009).
- [13] F. Kschischang, B. Frey, and H. A. Loeliger, IEEE Trans. Inf. Theory 47(2), 498 (2001).

变分平均场理论与置信传播

上一章介绍了腔方法以及它在计算多自旋相互作用模型近似自由能方面的应用. 这一近似等价于 Bethe 近似, 本章将对此作深入介绍. 本章把变分方法与平均场近似 (MFA) 和 Bethe 近似 (BA) 结合起来, 构造多自旋相互作用模型的自由能. 我们将说明, 计算机科学中的置信传播 (BP) 算法可以在变分框架下导出, 而且它实际上等价于物理学中的腔方法. 进一步还将强调, BA 是一种更精确的近似; 当耦合较弱或取高温极限时, 它退化为 MFA. 最后简要介绍逆 Ising 模型, 其中模型参数 (耦合与场) 可用平均场方法从数据中学习. BP 算法不仅是统计物理中的有用工具, 也是求解计算机科学、现代编码和神经网络学习中许多重要推断问题的高效方法; 后者正是本书的重点之一.

3.1 变分方法

变分方法 (variational method) 是统计推断问题中的一项重要技术. 给定待优化的目标函数以及问题必须满足的若干约束, 可以考察模型参数变化对目标函数的影响. 下面以统计物理中 Boltzmann 分布的推导为简单例子. 系统熵可定义为

$$S = -k \sum_r P_r \ln P_r, \quad (3.1)$$

其中 k 为 Boltzmann 常数, r 是热力学状态的指标, 而 P_r 是待确定的状态 r 的概率分布. 按照热力学理论, 系统在熵达到最大时处于平衡态; 该分布还必须满足

$$\sum_r P_r = 1, \quad (3.2)$$

$$\sum_r E_r P_r = \mu. \quad (3.3)$$

两式分别对应概率测度的归一化, 以及系统的目标平均能量水平 μ . 因而可采用 Lagrange 乘子法:

$$\mathcal{L} = S + \lambda_1 \left(\sum_r P_r - 1 \right) + \lambda_2 \left(\sum_r E_r P_r - \mu \right), \quad (3.4)$$

其中 λ_1 和 λ_2 分别是两个约束的 Lagrange 乘子. 平衡条件要求 $\partial \mathcal{L} / \partial P_r = 0$, 最终得到

$$\begin{aligned} P_r &= \frac{e^{-\beta E_r}}{Z}, \\ Z &= \sum_r e^{-\beta E_r}, \end{aligned} \quad (3.5)$$

其中逆温 $\beta = 1/(kT)$ 可由热力学第二定律推出, 而配分函数 Z 就是保证第一个约束成立的归一化常数. 以下讨论高维参数空间中的优化问题时, 取 $k = 1$.

总之, 利用 Lagrange 乘子法和少量平衡热力学知识, 便导出了著名的 Boltzmann 分布; 其中逆温显然调节系统的能量水平 [1].

3.2 变分自由能

自由能的行为决定热力学系统的涌现行为. 然而, 直接计算自由能需要 $O(2^N)$ 的计算复杂度, 因而不可处理. 为突破这一障碍, 变分方法提供了构造近似自由能的有效途径. 仍以此前的多自旋相互作用模型为例, 其 Boltzmann 分布为

$$P(\mathbf{x}) = \frac{e^{-\beta E(\mathbf{x})}}{Z}, \quad Z = \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})}, \quad (3.6)$$

其中 $\mathbf{x} = \{x_1, x_2, \dots, x_N\}$ 表示系统中 N 个自旋的状态. 能量为

$$E(\mathbf{x}) = - \sum_a J_a \prod_{i \in \partial a} x_i, \quad (3.7)$$

其中 a 是相互作用指标, $i \in \partial a$ 指定参与第 a 个相互作用的自旋集合, 并用 $\mathbf{x}_a$ 表示这些自旋; J_a 是第 a 个相互作用的耦合强度. 这里逆温可以任取; 等价地, 也可把温度吸收到耦合 J_a 中. 因而不失一般性地令 $\beta = 1$. 再定义 $f_a(\mathbf{x}_a) = e^{J_a \prod_{i \in \partial a} x_i}$, 它表示第 a 个相互作用对 Boltzmann 测度的贡献. 于是分布与能量可分别写成

$$P(\mathbf{x}) = \frac{1}{Z} \prod_a f_a(\mathbf{x}_a), \quad (3.8)$$

$$E(\mathbf{x}) = - \sum_a \ln f_a(\mathbf{x}_a). \quad (3.9)$$

这些表达式便于后面推导 BP 算法.

Helmholtz 自由能为

$$F_H = - \ln Z. \quad (3.10)$$

如上所述, 对大系统不可能精确计算 Helmholtz 自由能. 作为替代, 引入试探概率分布 $b(\mathbf{x})$, 并写出带有待优化参数 (例如磁化强度) 的自由能; 本书称之为 Gibbs 自由能:

$$F(b) = U(b) - H(b), \quad (3.11)$$

其中变分内能定义为

$$U(b) = \sum_{\mathbf{x}} b(\mathbf{x}) E(\mathbf{x}), \quad (3.12)$$

变分熵定义为

$$H(b) = - \sum_{\mathbf{x}} b(\mathbf{x}) \ln b(\mathbf{x}). \quad (3.13)$$

现在计算 Gibbs 自由能与 Helmholtz 自由能之差：

$$\begin{aligned}
F(b) - F_H &= \sum_{\mathbf{x}} b(\mathbf{x}) E(\mathbf{x}) + \sum_{\mathbf{x}} b(\mathbf{x}) \ln b(\mathbf{x}) + \ln Z \\
&= \sum_{\mathbf{x}} b(\mathbf{x}) [-\ln Z - \ln P(\mathbf{x})] + \sum_{\mathbf{x}} b(\mathbf{x}) \ln b(\mathbf{x}) + \ln Z \\
&= \sum_{\mathbf{x}} b(\mathbf{x}) \ln \frac{b(\mathbf{x})}{P(\mathbf{x})} = D(b\|P).
\end{aligned} \tag{3.14}$$

这里 $D(b\|P)$ 是概率分布 $b(\mathbf{x})$ 与 $P(\mathbf{x})$ 之间的 Kullback–Leibler 散度；它总是非负，并且当且仅当对所有 $\mathbf{x}$ 都有 $b(\mathbf{x}) = P(\mathbf{x})$ 时等于零。因而 $F(b) \geq F_H$ ，且仅在 $b = P$ 时取等号。

上述分析表明，使 Gibbs 自由能更低的试探分布 $b(\mathbf{x})$ ，与真实分布 $P(\mathbf{x})$ 的距离也 smaller。换言之，原来的自由能估计问题被转化成 Gibbs 自由能最小化问题。为得到更精确的自由能，必须寻找使 $F(b)$ 最小的 $b(\mathbf{x})$ ，这正是变分方法的目标。下一步需要引入可与物理量相联系的所谓变分参数，从而具体指定试探分布。以下各节介绍 $b(\mathbf{x})$ 的两种近似：平均场近似与 Bethe 近似。

3.2.1 平均场近似

对 $b(\mathbf{x})$ 的平均场近似写成因子化形式

$$b_{\text{MF}}(\mathbf{x}) = \prod_i b_i(x_i) = \prod_i \frac{1 + m_i x_i}{2}, \tag{3.15}$$

其中 $\mathbf{m}$ 是自旋 $\mathbf{x}$ 的磁化强度向量。这是朴素近似，它假定每个自旋彼此独立。注意 x_i 只能取 ± 1 两个值（例如分别表示自旋向上与向下）。给定 $b_{\text{MF}}(\mathbf{x})$ 的形式，平均场内能和平均场熵可计算为

$$\begin{aligned}
U_{\text{MF}} &= \sum_{\mathbf{x}} b_{\text{MF}}(\mathbf{x}) E(\mathbf{x}) \\
&= \sum_{\mathbf{x}} \prod_i b_i(x_i) \left(- \sum_a J_a \prod_{i \in \partial a} x_i \right) \\
&= - \sum_a J_a \left\langle \prod_{i \in \partial a} x_i \right\rangle \\
&= - \sum_a J_a \prod_{i \in \partial a} m_i,
\end{aligned} \tag{3.16}$$

以及

$$\begin{aligned}
H_{\text{MF}} &= - \sum_{\mathbf{x}} b_{\text{MF}}(\mathbf{x}) \ln b_{\text{MF}}(\mathbf{x}) \\
&= - \sum_{\mathbf{x}} \prod_i \frac{1 + m_i x_i}{2} \ln \prod_i \frac{1 + m_i x_i}{2} \\
&= - \sum_i \sum_{\mathbf{x}} \prod_j \frac{1 + m_j x_j}{2} \ln \frac{1 + m_i x_i}{2} \\
&= - \sum_i \sum_{x_i} \frac{1 + m_i x_i}{2} \ln \frac{1 + m_i x_i}{2} = \sum_i S_i,
\end{aligned} \tag{3.17}$$

其中 S_i 定义为自旋 x_i 的熵，而符号 $\setminus$ 表示排除操作。因而平均场自由能为

$$\begin{aligned}
F_{\text{MF}} &= U_{\text{MF}} - H_{\text{MF}} \\
&= - \sum_a J_a \prod_{i \in \partial a} m_i + \sum_i \sum_{x_i} \frac{1 + m_i x_i}{2} \ln \frac{1 + m_i x_i}{2}.
\end{aligned} \tag{3.18}$$

朴素平均场分布的因子化形式 [式 (3.15)] 自动满足归一化约束。磁化强度现在成为试探分布 $b_{\text{MF}}(\mathbf{x})$ 的变分参数。为使 Helmholtz 自由能的上界最小，需要计算 $\partial F_{\text{MF}} / \partial m_i$ 并令梯度为零：

$$\frac{\partial F_{\text{MF}}}{\partial m_i} = - \sum_{a \in \partial i} J_a \prod_{j \in \partial a \setminus i} m_j + \frac{1}{2} \ln \frac{1 + m_i}{1 - m_i} = 0, \tag{3.19}$$

最终得到 m_i 的递推形式

$$m_i = \tanh \left(\sum_{a \in \partial i} J_a \prod_{j \in \partial a \setminus i} m_j \right). \tag{3.20}$$

为求得 $\mathbf{m}$ 的不动点（平衡）值，可以迭代这些方程直至到达稳定点。利用平衡磁化强度即可求出 Gibbs 自由能的值 [2]。

然而，朴素平均场方法的自旋独立性假设未必准确，尤其是在关注低温热力学相时。因此需要考虑因子图短程区域内自旋之间的相关性，这恰是下一节将讨论的 Bethe 近似。

3.2.2 Bethe 近似

Bethe 近似 (Bethe approximation) [3] 是经典平均场方法的扩展，它考虑了最近邻格点之间的相关性。为介绍 Bethe 近似，先定义因子图中的区域 (region)。如图 3.1 所示，一个区域由一组函数节点以及与这些函数节点相连的全部变量节点定义；函数节点集合可以为空。在多自旋相互作用模型中，变量节点和函数节点分别表示自旋与相互作用。




图 3.1: 因子图中的区域. 实线圆定义为区域, 虚线圆不是有效区域.

在这一设定下, 区域能量 $E_R(\mathbf{x}_R)$ 、区域内能 $U_R(b_R)$ 、区域熵 $H_R(b_R)$ 和区域自由能 $F_R(b_R)$ 定义为

$$E_R(\mathbf{x}_R) = - \sum_{a \in R} \ln f_a(\mathbf{x}_a), \quad (3.21)$$

$$U_R(b_R) = \sum_{\mathbf{x}_R} b_R(\mathbf{x}_R) E_R(\mathbf{x}_R), \quad (3.22)$$

$$H_R(b_R) = - \sum_{\mathbf{x}_R} b_R(\mathbf{x}_R) \ln b_R(\mathbf{x}_R), \quad (3.23)$$

$$F_R(b_R) = U_R(b_R) - H_R(b_R), \quad (3.24)$$

其中 $\mathbf{x}_R$ 是区域 R 中的变量节点, $b_R(\mathbf{x}_R)$ 是 $\mathbf{x}_R$ 的联合分布.

基于区域的自由能近似, 其基本思想是把因子图分解为若干区域, 再将各区域的贡献求和以近似真实自由能; 每个变量节点与函数节点都只能被计数一次. 在非朴素近似中, 不同区域之间不可避免地存在重叠, 因而必须引入计数数 C_R (可为零或负的整数) 以避免重复计数. 给定区域集合 $\mathcal{R}$, 总内能 $U_{\mathcal{R}}$ 和总熵 $H_{\mathcal{R}}$ 可写为

$$U_{\mathcal{R}} = \sum_{R \in \mathcal{R}} C_R U_R(b_R), \quad (3.25)$$

$$H_{\mathcal{R}} = \sum_{R \in \mathcal{R}} C_R H_R(b_R), \quad (3.26)$$

计数数须满足

$$\sum_{R \in \mathcal{R}} I[a \in R] C_R = 1, \quad (3.27)$$

$$\sum_{R \in \mathcal{R}} I[i \in R] C_R = 1. \quad (3.28)$$

当函数节点 a 位于区域 R 中时 $I[a \in R] = 1$, 否则为零; $I[i \in R]$ 对变量节点具有类似含义.

在 Bethe 近似中, 因子图被分解为两类区域 (见图 3.2): 大区域 R_L 包含一个函数节点和与之相连的变量节点, 小区域 R_S 只包含一个变量节点. 这种划分给出 $C_{R_L} = 1$ 和 $C_{R_S} = 1 - d_i$, 其中 d_i 是与小区域中变量节点 i 相连的函数节点数. 这些计数数也可



图 3.2: Bethe 近似中的区域划分.

由恒等式 $C_R = 1 - \sum_{S \in \mathcal{S}(R)} C_S$ 导出, 其中 $\mathcal{S}(R)$ 是 R 的超区域集合; 若 R_1 中变量和函数节点的集合是 R_2 中节点集合的子集, 则 R_2 是 R_1 的超区域 [4].

于是 Bethe 内能和 Bethe 熵为

$$U_{\text{Bethe}} = - \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln f_a(\mathbf{x}_a), \quad (3.29)$$

$$H_{\text{Bethe}} = - \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln b_a(\mathbf{x}_a) + \sum_i (d_i - 1) \sum_{x_i} b_i(x_i) \ln b_i(x_i), \quad (3.30)$$

这里分别以 $b_a(\mathbf{x}_a)$ 和 $b_i(x_i)$ 代替 $b_{R_L}(\mathbf{x}_{R_L})$ 与 $b_{R_S}(\mathbf{x}_{R_S})$. Bethe 自由能因而为

$$\begin{aligned} F_{\text{Bethe}} = & - \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln f_a(\mathbf{x}_a) + \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln b_a(\mathbf{x}_a) \\ & - \sum_i (d_i - 1) \sum_{x_i} b_i(x_i) \ln b_i(x_i), \end{aligned} \quad (3.31)$$

它就是稍后要最小化的目标函数. 将最近邻相关性纳入考虑后, 试探概率分布还可紧凑地写成 [4, 5]

$$b_{\text{BA}}(\mathbf{x}) = \frac{\prod_a b_a(\mathbf{x}_a)}{\prod_i b_i(x_i)^{d_i-1}}. \quad (3.32)$$

该分布自动归一化; 当因子图为树时它是精确的, 即便因子图并非树状, 它通常仍是良好近似. 严格证明很困难, 实践中应将该近似与模拟比较. 将 $b_{\text{BA}}(\mathbf{x})$ 代入 Gibbs 自由能, 会得到与式 (3.31) 相同的形式.

在使用 Lagrange 乘子法之前, 先写出概率约束:

$$\sum_{x_i} b_i(x_i) = 1, \quad \forall i, \quad (3.33)$$

$$\sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) = 1, \quad \forall a, \quad (3.34)$$

$$\sum_{\mathbf{x}_a \setminus x_i} b_a(\mathbf{x}_a) = b_i(x_i), \quad \forall (i, a). \quad (3.35)$$

最终的 Lagrange 目标函数为

$$\begin{aligned} \mathcal{L} = & - \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln f_a(\mathbf{x}_a) + \sum_a \sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) \ln b_a(\mathbf{x}_a) \\ & - \sum_i (d_i - 1) \sum_{x_i} b_i(x_i) \ln b_i(x_i) + \sum_i \lambda_i \left[\sum_{x_i} b_i(x_i) - 1 \right] \\ & + \sum_a \lambda_a \left[\sum_{\mathbf{x}_a} b_a(\mathbf{x}_a) - 1 \right] + \sum_{i,a} \rho_{i,a}(x_i) \left[\sum_{\mathbf{x}_a \setminus x_i} b_a(\mathbf{x}_a) - b_i(x_i) \right]. \end{aligned} \quad (3.36)$$

对 $\mathcal{L}$ 作变分, 可得自旋分布 $b_i(x_i)$ 和联合分布 $b_a(\mathbf{x}_a)$ [4]:

$$b_i(x_i) = \frac{1}{Z_i} \prod_{a \in \partial i} P_{a \rightarrow i}(x_i), \quad (3.37a)$$

$$b_a(\mathbf{x}_a) = \frac{1}{Z_a} f_a(\mathbf{x}_a) \prod_{i \in \partial a} \prod_{b \in \partial i \setminus a} P_{b \rightarrow i}(x_i). \quad (3.37b)$$

如图 3.3 所示, 定义 $P_{a \rightarrow i}(x_i)$ 和 $P_{i \rightarrow a}(x_i)$ 为函数节点与变量节点之间沿两个方向传递的消息. 两种消息满足迭代方程

$$P_{a \rightarrow i}(x_i) = \sum_{\{x_j: j \in \partial a \setminus i\}} f_a(\mathbf{x}_a) \prod_{j \in \partial a \setminus i} P_{j \rightarrow a}(x_j), \quad (3.38a)$$

$$P_{i \rightarrow a}(x_i) = \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} P_{b \rightarrow i}(x_i). \quad (3.38b)$$




图 3.3: BP 算法中的消息传递过程. 左: 腔概率汇聚到变量节点; 右: 腔概率汇聚到函数节点.

式 (3.38a) 与写出受约束 Bethe 自由能时所用的边缘概率约束相容; 式 (3.38b) 则直接来自 $b_i(x_i)$ 的结果, 只需排除函数节点 a . 最终, 边缘 (联合边缘) 概率 $b_i(x_i)$ 、 $b_a(\mathbf{x}_a)$ 可解释为置信度, 并显式写成

$$b_i(x_i) \propto \prod_{a \in \partial i} P_{a \rightarrow i}(x_i), \quad (3.39a)$$

$$b_a(\mathbf{x}_a) \propto f_a(\mathbf{x}_a) \prod_{i \in \partial a} P_{i \rightarrow a}(x_i). \quad (3.39b)$$

这与式 (3.37) 一致.

式 (3.38) 在计算机科学中也称为置信传播 (belief propagation, BP) 算法. 可将消息集合 $\{P_{a \rightarrow i}(x_i), P_{i \rightarrow a}(x_i)\}$ 迭代至不动点, 再计算置信度 $b_i(x_i)$ 和 $b_a(\mathbf{x}_a)$. BP 算法的不动点对应受约束 Bethe 自由能的稳定点 [6]. 稳定点的数量依具体设定而异, 可能有限, 也可能呈指数增长. 例如, 若因子图含环, 或模型具有复杂低温相, BP 迭代可能不收敛, 或在若干解之间振荡. 腔方法可以扩展来处理指数多个状态的情形 (在物理学中对应一步复制对称破缺, 见第 9 章), 此时必须引入各状态上的腔场概率分布. 第 9 章将深入讨论这一点.

这里的消息 $P_{i \rightarrow a}(x_i)$ 可解释为移除函数节点 a 后变量节点 i 的概率分布, 与腔方法的定义相似. 事实上, 可以证明 BP 方程等价于腔方程. 首先把 $P_{b \rightarrow i}(x_i)$ 的表达式代

入 BP 方程中的 $P_{i \rightarrow a}(x_i)$, 得到

$$\begin{aligned} P_{i \rightarrow a}(x_i) &= \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \sum_{\{x_j: j \in \partial b \setminus i\}} f_b(\mathbf{x}_b) \prod_{j \in \partial b \setminus i} P_{j \rightarrow b}(x_j) \\ &= \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \sum_{\{x_j: j \in \partial b \setminus i\}} e^{J_b \prod_{j \in \partial b} x_j} \prod_{j \in \partial b \setminus i} \frac{1 + m_{j \rightarrow b} x_j}{2}. \end{aligned} \quad (3.40)$$

定义

$$A_b^+ = \sum_{\{x_j: j \in \partial b \setminus i\}} e^{J_b \prod_{j \in \partial b} x_j} \prod_{j \in \partial b \setminus i} \frac{1 + m_{j \rightarrow b} x_j}{2},$$

其中取 $x_i = +1$; A_b^- 在 $x_i = -1$ 时作类似定义. 因而 $Z_{i \rightarrow a} = \prod_{b \in \partial i \setminus a} A_b^+ + \prod_{b \in \partial i \setminus a} A_b^-$. 经过若干代数运算, 可分别写成

$$A_b^+ = \cosh J_b \left(1 + \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right), \quad (3.41)$$

$$A_b^- = \cosh J_b \left(1 - \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right). \quad (3.42)$$

这与上一章用腔方法得到的结果完全相同. 于是

$$\begin{aligned} m_{i \rightarrow a} &= \sum_{x_i} x_i P_{i \rightarrow a}(x_i) \\ &= \frac{\prod_{b \in \partial i \setminus a} A_b^+ - \prod_{b \in \partial i \setminus a} A_b^-}{\prod_{b \in \partial i \setminus a} A_b^+ + \prod_{b \in \partial i \setminus a} A_b^-} \\ &= \frac{\prod_{b \in \partial i \setminus a} \left(1 + \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right) - \prod_{b \in \partial i \setminus a} \left(1 - \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right)}{\prod_{b \in \partial i \setminus a} \left(1 + \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right) + \prod_{b \in \partial i \setminus a} \left(1 - \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right)}. \end{aligned} \quad (3.43)$$

引入辅助变量 $u_{b \rightarrow i}$, 满足 $\tanh u_{b \rightarrow i} = \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b}$, 最终得到

$$m_{i \rightarrow a} = \tanh \left(\sum_{b \in \partial i \setminus a} u_{b \rightarrow i} \right), \quad (3.44a)$$

$$\tanh u_{b \rightarrow i} = \tanh J_b \prod_{j \in \partial b \setminus i} m_{j \rightarrow b}, \quad (3.44b)$$

这正是 $\beta = 1$ 时的标准腔方程.

Bethe 近似只是更一般的簇变分方法中的成对近似 [5]. 簇变分方法能够处理任意大的相关格点簇, 但计算复杂度也随之增加. 近期发展还包括因子图上概率推断的环修正 [7, 8].

3.2.3 从 Bethe 近似到朴素平均场近似

朴素平均场近似采用因子化的试探概率分布，忽略自旋之间的相关性；Bethe 近似则考虑短程相关性。在高温下，即使这些短程相关性也应变得不重要，从而恢复朴素平均场近似。更具体地，以逆温为 β 的二体相互作用模型为例，平均场迭代方程为

$$m_i = \tanh \left(\beta \sum_{j \in \partial i} J_{ij} m_j \right). \quad (3.45)$$

下面从 Bethe 近似导出该方程。Bethe 近似中的腔迭代方程为

$$m_{i \rightarrow a} = \tanh \sum_{b \in \partial i \setminus a} u_{b \rightarrow i}, \quad (3.46a)$$

$$\tanh u_{b \rightarrow i} = \tanh(\beta J_b) \prod_{j \in \partial b \setminus i} m_{j \rightarrow b}. \quad (3.46b)$$

其中

$$\begin{aligned} m_{i \rightarrow a} &= \tanh \left(\sum_{b \in \partial i} u_{b \rightarrow i} - u_{a \rightarrow i} \right) \\ &= \tanh [\tanh^{-1}(m_i) - u_{a \rightarrow i}] \\ &= \frac{m_i - \tanh(\beta J_a) \prod_{j \in \partial a \setminus i} m_{j \rightarrow a}}{1 - m_i \tanh(\beta J_a) \prod_{j \in \partial a \setminus i} m_{j \rightarrow a}}, \end{aligned} \quad (3.47)$$

这里使用了恒等式 $\tanh(x + y) = [\tanh x + \tanh y] / [1 + \tanh x \tanh y]$ 。对于二体相互作用，

$$m_{i \rightarrow j} = \frac{m_i - \tanh(\beta J_{ij}) m_{j \rightarrow i}}{1 - m_i \tanh(\beta J_{ij}) m_{j \rightarrow i}}, \quad (3.48a)$$

$$m_{j \rightarrow i} = \frac{m_j - \tanh(\beta J_{ij}) m_{i \rightarrow j}}{1 - m_j \tanh(\beta J_{ij}) m_{i \rightarrow j}}. \quad (3.48b)$$

可以消去腔方程中的 $m_{i \rightarrow j}$ 和 $m_{j \rightarrow i}$ ，把它们写成单点磁化强度的函数。根据式 (3.48)[9]，

$$m_{i \rightarrow j} = f(m_i, m_j, \tanh \beta J_{ij}), \quad (3.49)$$

$$m_{j \rightarrow i} = f(m_j, m_i, \tanh \beta J_{ij}), \quad (3.50)$$

$$f(a, b, t) = \frac{1 - t^2 - \sqrt{(1 - t^2)^2 - 4t(a - bt)(b - at)}}{2t(b - at)}. \quad (3.51)$$

于是 m_i 的非腔形式为

$$m_i = \tanh \left[\sum_{j \in \partial i} \tanh^{-1}(f(m_j, m_i, \tanh \beta J_{ij}) \tanh \beta J_{ij}) \right]. \quad (3.52)$$

假设 βJ_{ij} 很弱（例如处于高温相），可对小量 x 使用 $\tanh^{-1} x \simeq x$ 、 $\tanh x \simeq x$ 与 $(1+x)^a \simeq 1+ax+\frac{1}{2}a(a-1)x^2$ 等 Taylor 展开，最终得到

$$m_i = \tanh \left[\sum_{j \in \partial i} (\beta J_{ij} m_j - \beta^2 J_{ij}^2 (1 - m_j^2) m_i) \right]. \quad (3.53)$$

求和中的第二项称为 Onsager 反应项（Onsager reaction term），是自旋玻璃模型高温展开解的特征 [10, 11]，后文将作更详细介绍。忽略耦合的二阶项，即恢复朴素平均场方程。

3.3 平均场逆 Ising 问题

前几节讨论了如何在若干近似下求平衡热力学问题的统计物理解，这正是正问题。反之，若从未知模型获得数据样本，便可由原始样本预测模型参数（例如耦合与外场），这称为逆问题（inverse problem）。正问题可为逆问题提供洞见，下面对此作更详细说明。

只考虑至多二体相互作用的 Ising 模型为

$$H(\sigma) = - \sum_{i < j} J_{ij} \sigma_i \sigma_j - \sum_i h_i \sigma_i, \quad (3.54a)$$

$$P(\sigma) = \frac{1}{Z} \exp \left(\sum_{i < j} J_{ij} \sigma_i \sigma_j + \sum_i h_i \sigma_i \right). \quad (3.54b)$$

这里 β 已吸收到模型参数中。给定测得的磁化强度 $m_i = \langle \sigma_i \rangle_{\text{data}}$ 和相关函数 $C_{ij} = \langle \sigma_i \sigma_j \rangle_{\text{data}} - m_i m_j$ ，目标是估计耦合常数和外场 $\{J_{ij}, h_i\}$ ，这是典型的无监督学习问题，也正是 Boltzmann 机器学习 [12]。它从一组初始参数 $\{J_{ij}, h_i\}$ 出发，按增量

$$\Delta J_{ij} = \eta (\langle \sigma_i \sigma_j \rangle_{\text{data}} - \langle \sigma_i \sigma_j \rangle_{\text{Ising}}), \quad (3.55a)$$

$$\Delta h_i = \eta (\langle \sigma_i \rangle_{\text{data}} - \langle \sigma_i \rangle_{\text{Ising}}) \quad (3.55b)$$

更新参数，其中 η 是预设学习率。迭代持续到模型平均与数据平均在给定精度内相符。模型平均可由后续章节将介绍的 Monte Carlo 算法估计；但当系统规模很大时，平均场方法相对更快。

为执行推断，先计算磁化强度

$$m_i = \frac{\partial \ln Z(J_{ij}^*, h_i^*)}{\partial h_i} = \sum_{\{\sigma\}} \sigma_i \frac{\exp \left(\sum_{i < j} J_{ij}^* \sigma_i \sigma_j + \sum_i h_i^* \sigma_i \right)}{Z}, \quad (3.56)$$

再应用涨落-响应定理 [13]：

$$\begin{aligned} \frac{\partial m_i}{\partial h_j} &= \sum_{\{\sigma\}} \sigma_i \sigma_j P(\sigma) - \sum_{\{\sigma\}} \sigma_i P(\sigma) \sum_{\{\sigma\}} \sigma_j P(\sigma) \\ &= C_{ij} = \langle \sigma_i \sigma_j \rangle_{\text{data}} - m_i m_j. \end{aligned} \quad (3.57)$$

上标 * 表示模型参数的当前估计. 这些步骤相当于标准期望最大化过程 [14] 中的期望步; 式 (3.55) 的更新过程则对应最大化步.

利用 $C_{ij} = \partial m_i / \partial h_j$ 和朴素平均场方程 $m_i = \tanh(h_i + \sum_{k \neq i} J_{ik} m_k)$, 可得

$$C_{ij} = (1 - m_i^2) \left(\delta_{ij} + \sum_{k \neq i} J_{ik} C_{kj} \right),$$

$$\mathbf{C} = \mathbf{P} + \mathbf{P} \mathbf{J} \mathbf{C}, \quad (3.58)$$

其中 $\mathbf{P}$ 是对角矩阵, $P_{ij} = (1 - m_i^2) \delta_{ij}$. 最终得到逆 Ising 问题的朴素平均场 (nMF) 解

$$J_{ij}^{\text{nMF}} = (\mathbf{P}^{-1})_{ij} - (\mathbf{C}^{-1})_{ij}. \quad (3.59)$$

随后可根据预测耦合重构外场. 在其他平均场方法中, 朴素平均场解是最简单的一种; 其他方法还包括高温展开、小相关展开和 Bethe 近似 [2, 15].

参考文献

- [1] J. M. Yeomans, *Statistical Mechanics of Phase Transitions* (Oxford University Press, Oxford, 1992).
- [2] H. Huang and Y. Kabashima, Phys. Rev. E 87, 062129 (2013).
- [3] H. A. Bethe, Proc. R. Soc. Lond. A 150(871), 552 (1935).
- [4] J. Yedidia, W. Freeman, and Y. Weiss, IEEE Trans. Inf. Theory 51(7), 2282 (2005).
- [5] A. Pelizzola, J. Phys. A 38(33), R309 (2005).
- [6] T. Heskes, Neural Comput. 16(11), 2379 (2004).
- [7] J. M. Mooij and H. J. Kappen, J. Mach. Learn. Res. 8(40), 1113 (2007).
- [8] J. Q. Xiao and H. Zhou, J. Phys. A 44(42), 425001 (2011).
- [9] F. Ricci-Tersenghi, J. Stat. Mech. 2012(8), P08015 (2012).
- [10] D. J. Thouless, P. W. Anderson, and R. G. Palmer, Philos. Mag. 35(3), 593 (1977).
- [11] T. Plefka, J. Phys. A 15(6), 1971 (1982).
- [12] D. H. Ackley, G. E. Hinton, and T. J. Sejnowski, Cognit. Sci. 9(1), 147 (1985).
- [13] H. J. Kappen and F. B. Rodríguez, *Advances in Neural Information Processing Systems*, 280–286 (1998).
- [14] A. P. Dempster, N. M. Laird, and D. B. Rubin, J. R. Stat. Soc. B 39, 1 (1977).
- [15] H. C. Nguyen, R. Zecchina, and J. Berg, Adv. Phys. 66(3), 197 (2017).

Monte Carlo 模拟方法

平衡态物理中只有少数系统能够解析求解，因此必须发展数值技术来估计物理系统的平衡性质。例如，即使已知 Ising 模型的 Hamiltonian，直接计算期望能量仍需 $O(2^N)$ 的时间复杂度，其中 N 为自旋数。无论是检验平均场近似或 Bethe 近似等粗略近似的精度，还是估计无法解析求解的统计力学模型的典型能量水平，都需要依赖 Monte Carlo 模拟及其变体。这些技术不仅广泛用于物理学，也广泛用于机器学习领域。例如，Gibbs 抽样可由经典 Monte Carlo 方法或借助重要性抽样的变体来实现。本章介绍抽样方法的基础知识及其在标准物理模型中的应用。

4.1 Monte Carlo 方法

Monte Carlo 方法的主要思想很简单。例如，多维积分可以通过按预先规定的分布抽取一组样本来计算。实现该方法的标准步骤为：

- 把感兴趣的原问题转化为统计问题，例如计算特定分布下某些随机变量的期望；
- 从该分布中抽取随机变量；
- 利用第二步得到的样本计算目标量，从而获得原问题的结果。

以估计积分或求和为代表性例子：

$$\langle A \rangle = \int A(x) f(x) dx, \quad (4.1a)$$

$$\langle A \rangle = \sum_x A(x) p(x). \quad (4.1b)$$

为计算上述期望，可从分布 $f(x)$ 或 $p(x)$ 中抽取随机变量，得到大小为 M 的样本集 $\{x_1, x_2, x_3, \dots, x_M\}$ ，进而得到 $\{A(x_1), A(x_2), A(x_3), \dots, A(x_M)\}$ 。由于各 $A(x_i)$ 独立估计，大数定律意味着

$$\lim_{M \rightarrow \infty} P \left(\left| \frac{1}{M} \sum_{i=1}^M A(x_i) - \langle A \rangle \right| < \epsilon \right) = 1, \quad \forall \epsilon > 0. \quad (4.2)$$

因此，期望可估计为

$$\langle A \rangle \simeq \frac{1}{M} \sum_i A(x_i). \quad (4.3)$$

由于所收集的样本独立同分布，抽样导致的统计误差与 A 的方差有关，其量级可估为 $O(M^{-1/2})$ [1]。此外，Monte Carlo 估计量是无偏的；当 Monte Carlo 样本数足够

大时, 经验估计收敛到目标真实期望 [2]. 读者可按上述过程估计积分 $\int_{-\infty}^{\infty} x^2 Dx$, 其中 Dx 表示 x 为标准 Gaussian 随机变量, 并将 Monte Carlo 估计与解析结果 1 比较. 随着随机样本数增加, 估计将趋近精确结果. 后续章节还将说明, 这类方法对于求解复制方法应用于多种神经网络模型时所得的鞍点方程, 同样非常有效且常用.

4.2 重要性抽样

Monte Carlo 模拟通常要求从某个分布中抽样, 例如上一节提到的 Gaussian 分布. 遗憾的是, 大多数分布都很难直接抽样, 统计物理中的 Boltzmann 分布便是一例. 下面介绍从比均匀、Poisson 和 Gaussian 分布更复杂的分布中产生随机样本的基本策略.

引入易于抽样的简单试探分布 $q(x)$, 可将式 (4.1) 改写为

$$\langle A \rangle = \int \frac{A(x)f(x)}{q(x)} q(x) dx, \quad (4.4a)$$

$$\langle A \rangle = \sum_x \frac{A(x)p(x)}{q(x)} q(x). \quad (4.4b)$$

期望 $\langle A \rangle_f$ 和 $\langle A \rangle_p$ 因而分别转化为 $\langle A(x)f(x)/q(x) \rangle_q$ 与 $\langle A(x)p(x)/q(x) \rangle_q$. 先从 $q(x)$ 抽取样本 $\{x_1, \dots, x_M\}$, 再计算

$$\langle A \rangle \simeq \frac{\sum_{i=1}^M A(x_i)p(x_i)/q(x_i)}{M}. \quad (4.5)$$

因子 $p(x_i)/q(x_i)$ 可视为样本 x_i 在期望计算中的重要性权重, 所以该估计称为重要性抽样 (importance sampling) [2]. 当 $q(x_i) = p(x_i)$ 时, 它退化为式 (4.3). 试探分布的选择非常重要; 若选择不当, Monte Carlo 估计会因方差很大而噪声强烈, 并极慢地收敛到令人满意的精度.

退火重要性抽样 (annealed importance sampling) 从一个平凡分布 $p_0(x)$ 出发构造合适的 $q(x)$. 指定中间分布的一种常见方案为

$$p_j(x) = p_0(x)^{1-\beta_j} p_n(x)^{\beta_j}, \quad (4.6)$$

其中 $0 = \beta_0 < \beta_1 < \dots < \beta_n = 1$. 换言之, $p_j(x)$ 在 $p_0(x)$ 与 $p_n(x) = p(x)$ 之间插值. 随后可通过设计合适的两状态转移概率, 依次产生样本; 实现细节见原始论文 [3].

4.3 Markov 链抽样

为了实现依次产生一串样本的抽样, 可以在抽样过程中构造 Markov 链. Markov 性质意味着动力学的下一状态只与当前状态有关, 其条件概率为

$$P(S_{t+1} | S_1, \dots, S_t) = P(S_{t+1} | S_t), \quad (4.7)$$

其中 S_t 是时刻 t 的状态. Markov 链的动力学遵从这一性质. 给定初始分布 $\pi(S_0)$ 和转移概率 $W(S \rightarrow S')$, 即可构造时间齐次 Markov 链; 满足

$$\pi(S') = \sum_S W(S \rightarrow S') \pi(S) \quad (4.8)$$

的 $\pi(S')$ 是平稳分布. 若满足细致平衡 (detailed balance) 条件

$$W(S \rightarrow S')\pi(S) = W(S' \rightarrow S)\pi(S'), \quad (4.9)$$

则 Markov 链的设计变得简单 [1]. 细致平衡条件保证所设计的 Markov 链收敛到目标分布 [式 (4.8)].

4.4 统计物理中的 Monte Carlo 模拟

统计物理中的平衡系统由 Boltzmann 分布描述:

$$P_{\text{eq}}(\mathbf{s}) = \frac{1}{Z} e^{-\beta H(\mathbf{s})}, \quad (4.10)$$

其中配分函数 $Z = \sum_{\mathbf{s}} e^{-\beta H(\mathbf{s})}$, $H(\mathbf{s})$ 是系统的 Hamiltonian. 可观测量 $O(\mathbf{s})$ 的期望或热平均为

$$\langle O \rangle = \frac{1}{Z} \sum_{\mathbf{s}} O(\mathbf{s}) e^{-\beta H(\mathbf{s})}. \quad (4.11)$$

配分函数通常不可处理, 使热力学量无法解析估计. Markov 链 Monte Carlo (MCMC) 因而适合估计目标量.

以模拟 SK 模型说明 MCMC 方法. SK 模型是全连接平均场玻璃模型, 其统计力学性质最早在开创性工作 [4] 中得到解析研究. Hamiltonian 为

$$H = -\frac{1}{2} \sum_{i \neq j} J_{ij} \sigma_i \sigma_j, \quad (4.12)$$

其中 $\sigma_i = \pm 1$, 耦合独立服从均值为零、方差为 $1/N$ 的 Gaussian 分布. 该模型在临界温度 $T = 1$ 发生从顺磁相到自旋玻璃相的转变. 利用 MCMC 方法可得到 SK 模型的平衡性质, 并与理论分析比较. 下面介绍两种数值评估模型的 Monte Carlo 技术; 二者也普遍适用于无法精确计算相关热力学量的其他类似模型.

4.4.1 Metropolis 算法

Boltzmann 分布的细致平衡条件可写为

$$P_{\text{eq}}(s_i)W(s_i \rightarrow s_j) = P_{\text{eq}}(s_j)W(s_j \rightarrow s_i), \quad (4.13)$$

其中 $W(s_i \rightarrow s_j)$ 是从状态 s_i 到状态 s_j 的转移概率. 利用 Boltzmann 分布, 两个转移概率之比为

$$\frac{W(s_i \rightarrow s_j)}{W(s_j \rightarrow s_i)} = e^{-\beta \Delta H(s_i, s_j)}, \quad (4.14)$$

其中 $\Delta H(s_i, s_j) = H(s_j) - H(s_i)$. 目标是找到满足细致平衡的转移概率矩阵, 而选择并不唯一. 常用形式之一是 Metropolis 算法 (Metropolis algorithm):

$$W(s_i \rightarrow s_j) = \begin{cases} 1, & \Delta H(s_i, s_j) < 0, \\ e^{-\beta \Delta H(s_i, s_j)}, & \Delta H(s_i, s_j) \geq 0, \end{cases} \quad (4.15)$$

也可写成 $W(s_i \rightarrow s_j) = \min(e^{-\beta\Delta H(s_i, s_j)}, 1)$. 另一种常用选择是热浴算法:

$$W(s_i \rightarrow s_j) = \frac{e^{-\beta\Delta H(s_i, s_j)}}{1 + e^{-\beta\Delta H(s_i, s_j)}}. \quad (4.16)$$

可以验证, Metropolis 动力学总是更可能接受能量变化较小的自旋改变尝试. 此外, 若将转移概率定义为 $F(e^{-\beta\Delta H})$, 可验证上述两种选择对任意 x 都满足 $F(x)/F(1/x) = x$, 与细致平衡条件相容.

为快速抽样, Metropolis 动力学的每一步只翻转单个自旋, 而非一小组自旋. 由热浴选择可得转移规则

$$W(\sigma_i \rightarrow -\sigma_i) = \frac{1}{2}[1 - \sigma_i \tanh(\beta h_i)], \quad (4.17)$$

其中 $h_i = \sum_{j \neq i} J_{ij} \sigma_j$ 是作用于自旋 σ_i 的局域场.

算法 4.1 Metropolis 算法

输入: 样本数 M 、温度 T 、 τ_{eq} 、 δt .

输出: 样本集合.

1. 随机初始化构型 S , 令 $i = 0$ 、counter = 0.
2. 当 $i < M$ 时, 产生试探状态 S' , 计算 $W(S' \rightarrow S | T)$.
3. 若 $W > \text{rand}(0, 1)$, 令 $S = S'$.
4. 若 counter $> \tau_{\text{eq}}$ 且 counter mod $\delta t = 0$, 则把 S 加入样本集合, 并令 $i = i + 1$.
5. 令 counter = counter + 1, 返回步骤 2.
6. 返回样本集合.

随机初态以很高概率远离平衡, 因此 Markov 链动力学需要一段弛豫时间使系统到达平衡, 这一时间尺度称为平衡化时间 τ_{eq} . 实际中用 Monte Carlo 扫描 (MCS) 作单位: 一次 MCS 等于 N 次提议的单自旋更新. 为验证系统是否达到平衡, 需要考察能量等可观测量的演化.

如图 4.1(a) 所示, SK 模型的能量约在 τ_{eq} 个 MCS 后达到平衡, 该时间依赖温度. 弛豫后, 能量围绕理论可预测的典型值涨落. 因此可以在 τ_{eq} 个 MCS 后收集样本, 估计目标热力学量的平衡值.

即使动力学已达到稳态, 相邻两次抽样之间仍需间隔一定数量的 MCS, 才能独立抽取平衡态. 因此须计算任意可观测量 O 的含时自相关函数

$$C_O(t) = \frac{\langle O(t_0)O(t_0+t) \rangle - \langle O(t_0) \rangle \langle O(t_0+t) \rangle}{\langle O^2(t_0) \rangle - \langle O(t_0) \rangle^2}, \quad (4.18)$$

其中 $\langle \cdot \rangle$ 表示热平均, t_0 为起始时间. 一般而言, $C_O(t) \sim \exp(-t/\tau_{\text{auto}})$, 其中 τ_{auto} 是相应时间尺度. 连续相变处相关长度发散, 自相关时间也随之发散, 这称为临界慢化 (critical slowing down).




图 4.1: SK 模型能量密度的演化, 其中 $N = 500$, $J_{ij} \sim \mathcal{N}(0, 1/N)$. (a) Metropolis Monte Carlo 模拟; (b) 并行回火 Monte Carlo. 虚线是复制理论的相应预测. 时间步以 MCS 为单位, 每一步表示对全部自旋作一轮提议更新; β 为逆温.

在玻璃物理中, Edwards–Anderson 序参量 $q_{\text{EA}} = N^{-1} \sum_i \langle \sigma_i \rangle^2$ [5] 可视为含时自相关函数的长时极限 $q_{\text{EA}} = \lim_{t \rightarrow \infty} C(t)$, 其中 $C(t) = N^{-1} \sum_i \langle \sigma_i(0) \sigma_i(t) \rangle$. 它还可用于探测遍历性破缺. 图 4.2 给出了 SK 模型在不同温度下的典型自相关曲线.




图 4.2: 图 4.1 所定义的同一 SK 模型的自相关函数弛豫动力学.

4.4.2 并行回火 Monte Carlo

研究自旋玻璃模型 (例如 SK 模型、Hopfield 模型等) 的低温相时, 一旦 Gibbs 测度分解为数量随自由度指数增长的亚稳态, Metropolis 算法便容易陷入局域极小值. 一般不存在一种高效局域动力学方法能解决这一困难的公平抽样问题, 但存在多种启发式抽样方法. 著名例子是模拟退火 [6]: Metropolis 抽样的初始温度远高于目标低温, 动力学在逐步降低的每个中间温度运行若干 MCS, 最终期望由退火过程到达能量更低的基态.

另一种更高效的方法是并行回火 (parallel tempering) [7], 它通过在不同温度下模拟原系统的多个副本来跨越能垒. 取 M 个互不作用、因而彼此独立的副本构成系综. 第 m 个副本具有原 Hamiltonian $H(X_m)$, 并服从逆温为 β_m 的 Boltzmann 分布; 为方便起见, 令 $\beta_m < \beta_{m+1}$. 系综状态为扩展状态 $\{X\} = \{X_1, \dots, X_M\}$, 其配分函数为

$$Z = \sum_{\{X\}} \exp \left[- \sum_{m=1}^M \beta_m H(X_m) \right] = \prod_{m=1}^M Z(\beta_m), \quad (4.19)$$

其中 $Z(\beta_m)$ 是逆温为 β_m 时原系统的配分函数. 给定温度集合的扩展状态概率为

$$P(\{X, \beta\}) = \prod_{m=1}^M P_{\text{eq}}(X_m, \beta_m) = \frac{1}{Z} \exp \left[- \sum_{m=1}^M \beta_m H(X_m) \right]. \quad (4.20)$$

构造细致平衡条件时, 只考虑交换两个副本的构型. 例如, 扩展状态 $\{\dots; X, \beta_m; \dots; X', \beta_n; \dots\}$ 以转移概率 $W(X', \beta_m; X, \beta_n | X, \beta_m; X', \beta_n)$ 变为 $\{\dots; X', \beta_m; \dots; X, \beta_n; \dots\}$. 细致平衡条件为

$$\begin{aligned} & P(\{\dots; X, \beta_m; \dots; X', \beta_n; \dots\}) W(X', \beta_m; X, \beta_n | X, \beta_m; X', \beta_n) \\ &= P(\{\dots; X', \beta_m; \dots; X, \beta_n; \dots\}) W(X, \beta_m; X', \beta_n | X', \beta_m; X, \beta_n). \end{aligned} \quad (4.21)$$

由此容易导出

$$\frac{W(X', \beta_m; X, \beta_n | X, \beta_m; X', \beta_n)}{W(X, \beta_m; X', \beta_n | X', \beta_m; X, \beta_n)} = e^{-\Delta}, \quad (4.22)$$

其中

$$\Delta = (\beta_n - \beta_m)[H(X) - H(X')]. \quad (4.23)$$

一种合理的转移概率选择是

$$W(X', \beta_m; X, \beta_n | X, \beta_m; X', \beta_n) = \begin{cases} 1, & \Delta < 0, \\ e^{-\Delta}, & \Delta > 0. \end{cases} \quad (4.24)$$

综上, 并行回火 Monte Carlo 可按如下过程实现. 首先以传统 MCMC (例如 Metropolis 方法) 对系综中每个副本模拟若干 MCS; 然后以 $W(X', \beta_m; X, \beta_{m+1} | X, \beta_m; X', \beta_{m+1})$ 交换两个相邻温度的构型. 一般而言, 任意两个不同温度 T_n, T_m 的副本及其微观构型都可以交换温度 [8]. 非相邻副本的温度交换概率指数减小, 但对加速跨越高能垒仍很重要 [8]. 最终, 任意可观测量 O 的期望为

$$\langle O \rangle_{\beta_m} = \frac{1}{M} \sum_{t=1}^M O(X_m(t)). \quad (4.25)$$

算法 4.2 并行回火 Monte Carlo

输入：样本数 L 、 $\beta_{\max}$ 、 $\beta_{\min}$ 和温度数 M .

输出：样本集合.

1. 初始化 $\beta_1 = \beta_{\min}$ 、 $\beta_M = \beta_{\max}$ ，并线性设置 $\beta_m = \beta_1 + (\beta_M - \beta_1)(m-1)/(M-1)$.
2. 随机初始化扩展状态 $\{X\} = \{X_1, \dots, X_M\}$ ，令 $i = 0$.
3. 当 $i < L$ 时，对每个副本应用 MCMC 若干 MCS.
4. 对 $\beta_m \in \{\beta_1, \dots, \beta_{M-1}\}$ ，计算 $\Delta = (\beta_{m+1} - \beta_m)[H(X_m) - H(X_{m+1})]$.
5. 若 $e^{-\Delta} > \text{rand}(0, 1)$ ，交换 X_m 与 X_{m+1} .
6. 将 $\{X\}$ 加入样本集合，令 $i = i + 1$ ，返回步骤 3.
7. 返回样本集合.

高温相动力学快，低温相则因势能景观崎岖而非常慢. 为保证适当的接受率，接受概率 $e^{-\Delta}$ 应为一阶量. 由式 (4.23)，

$$-\Delta = \delta[H(X_{n+1}) - H(X_n)] \sim \delta^2 \frac{dE}{d\beta}, \quad (4.26)$$

其中 δ 表示很小的逆温差， $E = \langle H \rangle$ 是广延的平均热能. 为使接受概率为一阶量，相邻温度之差 δ 应为 $O(N^{-1/2})$ ，这意味着需要 $O(\sqrt{N})$ 个副本 [7]. 本质上，快速混合链产生的新构型使低温链能比纯 Metropolis 局域动力学更高效地抽取状态空间.

参考文献

- [1] U. von Toussaint, Rev. Mod. Phys. 83(3), 943 (2011).
- [2] H. G. Katzgraber, arXiv:0905.1629 (2009).
- [3] R. M. Neal, Stat. Comput. 11(2), 125 (2001).
- [4] D. Sherrington and S. Kirkpatrick, Phys. Rev. Lett. 35(26), 1792 (1975).
- [5] S. F. Edwards and P. W. Anderson, J. Phys. F 5(5), 965 (1975).
- [6] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, Science 220(4598), 671 (1983).
- [7] K. Hukushima and K. Nemoto, J. Phys. Soc. Jpn. 65(6), 1604 (1996).
- [8] C. E. Fiore and M. G. E. da Luz, Phys. Rev. E 82, 031104 (2010).

高温展开

本章介绍一项重要理论技术—高温展开 (high-temperature expansion)，并用它推导标准自旋玻璃理论中的奠基性方程 Thouless–Anderson–Palmer (TAP) 方程 [1, 2, 3]. 这项技术在机器学习领域同样常用而有效，可作为微扰分析工具导出高效推断与学习算法 [4].

5.1 统计物理设定

统计物理中，给定 Hamiltonian H ，相应配分函数定义为

$$Z = \sum_{\sigma} e^{-\beta H(\sigma)}, \quad (5.1)$$

它是 Boltzmann 分布的归一化常数. 逆温 $\beta = 1/T$ ， σ 表示构型向量. 任意热力学量 $A(\sigma)$ 关于 Boltzmann 分布的平均为

$$\langle A \rangle = \sum_{\sigma} A(\sigma) P(\sigma), \quad (5.2)$$

其中 $P(\sigma) = e^{-\beta H(\sigma)}/Z$. 内能因而定义为

$$E(\beta) = \langle H \rangle = \sum_{\sigma} H(\sigma) P(\sigma). \quad (5.3)$$

按概率解释，熵定义为

$$S(\beta) = - \sum_{\sigma} P(\sigma) \ln P(\sigma). \quad (5.4)$$

Helmholtz 自由能于是为

$$F(\beta) = E(\beta) - TS(\beta) = -\frac{1}{\beta} \ln Z(\beta). \quad (5.5)$$

在神经网络等复杂系统中，Boltzmann 分布通常难以计算，甚至难以从中均匀抽样. 变分方法则以属于可处理分布族 $\mathcal{M}$ 的 $Q(\sigma)$ 近似不可处理的 $P(\sigma)$. 在 $\mathcal{M}$ 内选择 Q ，使某种距离度量 $D(Q, P)$ 最小. 例如，可取 Q 与 P 的 Kullback–Leibler (KL) 散度：

$$\text{KL}(Q\|P) = \sum_{\sigma} Q(\sigma) \ln \frac{Q(\sigma)}{P(\sigma)} = \left\langle \ln \frac{Q}{P} \right\rangle_Q, \quad (5.6)$$

其中 $\langle \cdots \rangle_Q$ 表示关于 Q 的期望. 将 $P(\sigma) = e^{-\beta H(\sigma)}/Z$ 代入式 (5.6)，得到

$$\text{KL}(Q\|P) = \ln Z + \beta E[Q] - S[Q] = \ln Z + \beta F[Q], \quad (5.7)$$

其中变分能量与试探分布的熵分别为

$$E[Q] = \sum_{\sigma} Q(\sigma) H(\sigma), \quad (5.8)$$

$$S[Q] = - \sum_{\sigma} Q(\sigma) \ln Q(\sigma). \quad (5.9)$$

变分自由能为

$$F[Q] = E[Q] - TS[Q]. \quad (5.10)$$

由于 KL 散度非负, $F[Q]$ 构成 Helmholtz 自由能的上界; 当 $Q = P$ 时界为紧的.

进一步定义分布 Q 下的 Gibbs 自由能

$$G_{\beta}(\mathbf{m}) = \min_{Q} \{F[Q] \mid \langle \sigma \rangle_Q = \mathbf{m}\}. \quad (5.11)$$

Helmholtz 自由能只是平衡时等于 $E - TS$ 的热力学数值; Gibbs 自由能则是在施加磁化强度等约束时给出 $E - TS$ 数值的函数. 与直接计算 Helmholtz 自由能相比, 使用 Gibbs 自由能更容易施加直观近似.

下面最小化 Gibbs 自由能. 首先固定 $\mathbf{m}$, 把最小化限制在满足 $\langle \sigma \rangle_Q = \mathbf{m}$ 的分布族内. 引入 Lagrange 乘子 λ :

$$\begin{aligned} G_{\beta}(\mathbf{m}, \lambda) &= E[Q] - TS[Q] - \frac{1}{\beta} \sum_i \lambda_i (\langle \sigma_i \rangle_Q - m_i) \\ &= \sum_{\sigma} Q(\sigma) \left[H(\sigma) - \frac{1}{\beta} \sum_i \lambda_i \sigma_i \right] - TS[Q] + \frac{1}{\beta} \sum_i \lambda_i m_i. \end{aligned} \quad (5.12)$$

式 (5.12) 具有式 (5.10) 的变分自由能形式, 只是 $H(\sigma)$ 被 $H(\sigma) - \sum_i \lambda_i \sigma_i / \beta$ 代替. 因而有效分布为

$$Q_{\lambda}(\sigma) = \frac{\exp[-\beta H(\sigma) + \sum_i \lambda_i \sigma_i]}{Z_{\lambda}}, \quad (5.13)$$

其中 $Z_{\lambda} = \sum_{\sigma} \exp[-\beta H(\sigma) + \sum_i \lambda_i \sigma_i]$. 这是因为当 Q 为 Boltzmann 分布 P 时, 变分自由能达到最小. 将该分布代回式 (5.12):

$$\begin{aligned} G_{\beta}(\mathbf{m}, \lambda) &= -\frac{1}{\beta} \ln \sum_{\sigma} e^{-\beta H(\sigma) + \sum_i \lambda_i \sigma_i} + \frac{1}{\beta} \sum_i \lambda_i m_i \\ &= -\frac{1}{\beta} \ln \sum_{\sigma} e^{-\beta H(\sigma) + \sum_i \lambda_i \sigma_i - \sum_i \lambda_i m_i}. \end{aligned} \quad (5.14)$$

约束由 Lagrange 乘子 λ 强制, 其取值由

$$\beta G_{\beta}(\mathbf{m}) = \max_{\lambda} \left[-\ln \sum_{\sigma} e^{-\beta H(\sigma) + \sum_i \lambda_i \sigma_i} + \sum_i \lambda_i m_i \right] \quad (5.15)$$

确定. 取最大值与 Hessian 矩阵的性质有关. 对 Lagrangian 求导:

$$\frac{\partial[-\beta G_\beta(\mathbf{m}, \boldsymbol{\lambda})]}{\partial \lambda_i} = \langle \sigma_i \rangle_Q - m_i = 0 \implies m_i = \langle \sigma_i \rangle_Q, \quad (5.16)$$

$$\frac{\partial[-\beta G_\beta(\mathbf{m}, \boldsymbol{\lambda})]}{\partial m_i} = \sum_j \frac{\partial \lambda_j}{\partial m_i} (\langle \sigma_j \rangle_\lambda - m_j) - \lambda_i = -\lambda_i = 0, \quad (5.17)$$

其中定义 $-\beta F_\beta(\boldsymbol{\lambda}) = \ln Z_\lambda$. 最终得到

$$\min_{\mathbf{m}} G_\beta(\mathbf{m}) = F[P] = -\frac{1}{\beta} \ln Z. \quad (5.18)$$

注意 $G_\beta(\mathbf{m})$ 是凸函数, 在平衡磁化强度 $\mathbf{m}_{\text{eq}}$ 处具有唯一极小值. 因而, 对 $G_\beta(\mathbf{m})$ 的近似计算也能给出真实自由能 $F[P]$ 的近似.

5.2 高温展开

本节用高温展开近似真实 Helmholtz 自由能. 先介绍奠基性的 Sherrington–Kirkpatrick (SK) 模型. 它于 1975 年作为自旋玻璃的简单模型提出 [5], 本质上是具有无序耦合的 Ising 模型. 为简化起见, 这里忽略外场. Hamiltonian 为

$$H(\boldsymbol{\sigma}) = -\sum_{i<j}^N J_{ij} \sigma_i \sigma_j, \quad (5.19)$$

其中 $i < j$ 时耦合 J_{ij} 彼此独立, 并服从均值为 J_0 (这里令 $J_0 = 0$)、方差为 J^2/N 的 Gaussian 分布. J_{ij} 是模型的淬火无序.

Gibbs 自由能不可处理, 使磁化空间中的优化也很困难. 因此需要对自由能作微扰分析, 例如关于高温展开; 纳入更高阶展开可控制近似精度. 定义与 Hamiltonian 关联的新配分函数

$$\tilde{Z}_\beta = \sum_{\boldsymbol{\sigma}} e^{-\beta \tilde{H}(\boldsymbol{\sigma})}, \quad (5.20)$$

修正 Hamiltonian 为

$$\begin{aligned} \tilde{H}(\boldsymbol{\sigma}) &= H(\boldsymbol{\sigma}) - \sum_i \frac{\lambda_i(\beta)}{\beta} (\sigma_i - m_i) \\ &= -\frac{1}{2} \sum_{i \neq j} J_{ij} \sigma_i \sigma_j - \sum_i \frac{\lambda_i(\beta)}{\beta} (\sigma_i - m_i). \end{aligned} \quad (5.21)$$

这里把 $\lambda_i(\beta)$ 显式写成温度的函数, 因为 λ_i 用于强制依赖温度的磁化强度. Gibbs 自由能与新配分函数的关系为

$$-\beta G_\beta(\mathbf{m}, \boldsymbol{\lambda}) = \ln \tilde{Z}_\beta. \quad (5.22)$$

在 $\beta = 0$ 处作 Taylor 展开:

$$-\beta G_\beta(\mathbf{m}) = \ln \tilde{Z}_\beta \Big|_{\beta=0} + \frac{\partial \ln \tilde{Z}_\beta}{\partial \beta} \Big|_{\beta=0} \beta + \frac{\partial^2 \ln \tilde{Z}_\beta}{\partial \beta^2} \Big|_{\beta=0} \frac{\beta^2}{2} + \dots \quad (5.23)$$

在 $\beta = 0$ 时,

$$\begin{aligned}\tilde{Z}_\beta \Big|_{\beta=0} &= \sum_{\sigma} e^{\sum_i \lambda_i (\sigma_i - m_i)} = \prod_i \sum_{\sigma_i} e^{\lambda_i (\sigma_i - m_i)} \\ &= \prod_i e^{-\lambda_i m_i} (2 \cosh \lambda_i).\end{aligned}\quad (5.24)$$

由于

$$\frac{\partial \ln \tilde{Z}_{\beta=0}}{\partial \lambda_i} = -m_i + \tanh \lambda_i = 0 \quad \implies \quad \begin{cases} m_i = \tanh \lambda_i, \\ \lambda_i = \operatorname{atanh} m_i, \end{cases} \quad (5.25)$$

第一项为

$$\ln \tilde{Z}_\beta \Big|_{\beta=0} = - \sum_i \left[\frac{1+m_i}{2} \ln \frac{1+m_i}{2} + \frac{1-m_i}{2} \ln \frac{1-m_i}{2} \right]. \quad (5.26)$$

这里使用了 $\operatorname{atanh} m_i = \frac{1}{2} \ln[(1+m_i)/(1-m_i)]$. 第二项为

$$\left. \frac{\partial \ln \tilde{Z}_\beta}{\partial \beta} \right|_{\beta=0} = - \langle H \rangle|_{\beta=0} = \frac{1}{2} \sum_{i \neq j} J_{ij} m_i m_j. \quad (5.27)$$

热平均在 $\tilde{H}(\sigma)$ 的 Boltzmann 测度下进行; 在高温极限, 两自旋间的相关性可忽略.

第三项为

$$\begin{aligned}\frac{\partial^2 \ln \tilde{Z}_\beta}{\partial \beta^2} &= - \frac{\partial \langle H \rangle}{\partial \beta} \\ &= \left\langle \left[H - \langle H \rangle - \sum_i \frac{\partial \lambda_i}{\partial \beta} (\sigma_i - m_i) \right] H \right\rangle \equiv \langle u H \rangle.\end{aligned}\quad (5.28)$$

这里引入有用的算子 [3]

$$u \equiv H - \langle H \rangle - \sum_i \frac{\partial \lambda_i}{\partial \beta} (\sigma_i - m_i) = H - \langle H \rangle - k, \quad (5.29)$$

其中 $k \equiv \sum_i (\partial \lambda_i / \partial \beta) (\sigma_i - m_i)$. 又因为

$$\frac{\partial \ln \tilde{Z}_\beta}{\partial m_i} = -\lambda_i \frac{\tilde{Z}_\beta}{\tilde{Z}_\beta} = -\lambda_i, \quad (5.30)$$

所以

$$\begin{aligned}\left. \frac{\partial \lambda_i}{\partial \beta} \right|_{\beta=0} &= - \frac{\partial}{\partial \beta} \frac{\partial \ln \tilde{Z}_\beta}{\partial m_i} = - \frac{\partial}{\partial m_i} \frac{\partial \ln \tilde{Z}_\beta}{\partial \beta} \\ &= - \frac{1}{2} \frac{\partial}{\partial m_i} \sum_{k \neq l} J_{kl} m_k m_l = - \sum_{j \neq i} J_{ij} m_j.\end{aligned}\quad (5.31)$$

因而

$$\begin{aligned}
u|_{\beta=0} &= -\frac{1}{2} \sum_{i \neq j} J_{ij} \sigma_i \sigma_j + \frac{1}{2} \sum_{i \neq j} J_{ij} m_i m_j + \sum_i \sum_{j \neq i} J_{ij} m_j (\sigma_i - m_i) \\
&= -\frac{1}{2} \sum_{i \neq j} J_{ij} (\sigma_i - m_i) (\sigma_j - m_j).
\end{aligned} \tag{5.32}$$

继续计算 u 的均值与方差：

$$\langle u \rangle = 0, \tag{5.33}$$

$$\langle u^2 \rangle = \langle u(H - \langle H \rangle - k) \rangle = \langle uH \rangle - \langle u \rangle \langle H \rangle - \langle ku \rangle = \langle uH \rangle. \tag{5.34}$$

可用恒等式

$$\frac{d}{d\beta} \langle O \rangle = \left\langle \frac{\partial O}{\partial \beta} \right\rangle - \langle Ou \rangle \tag{5.35}$$

证明式 (5.33) 和 (5.34)，其中 O 是任意可观测量。由于磁化强度受约束而为常数，

$$\begin{aligned}
\frac{d}{d\beta} \langle \sigma_i \rangle &= 0 = -\langle \sigma_i u \rangle, \\
\langle (\sigma_i - m_i) u \rangle &= 0, \quad \langle ku \rangle = 0.
\end{aligned} \tag{5.36}$$

于是可由 $\langle u^2 \rangle_{\beta=0}$ 计算第三项：

$$\begin{aligned}
\left. \frac{\partial^2 \ln \tilde{Z}_\beta}{\partial \beta^2} \right|_{\beta=0} &= \langle u^2 \rangle|_{\beta=0} \\
&= \frac{1}{4} \sum_{\substack{i \neq j \\ k \neq l}} J_{ij} J_{kl} \langle (\sigma_i - m_i) (\sigma_j - m_j) (\sigma_k - m_k) (\sigma_l - m_l) \rangle \\
&\simeq \frac{1}{2} \sum_{i \neq j} J_{ij}^2 \langle (\sigma_i - m_i)^2 (\sigma_j - m_j)^2 \rangle \\
&= \frac{1}{2} \sum_{i \neq j} J_{ij}^2 (1 - m_i^2) (1 - m_j^2).
\end{aligned} \tag{5.37}$$

这里使用 $\langle (\sigma_i - m_i)^2 \rangle = 1 - m_i^2$ 。最终得到

$$\begin{aligned}
-\beta G_\beta(\mathbf{m}) &= -\sum_i \left[\frac{1+m_i}{2} \ln \frac{1+m_i}{2} + \frac{1-m_i}{2} \ln \frac{1-m_i}{2} \right] \\
&\quad + \frac{\beta}{2} \sum_{i \neq j} J_{ij} m_i m_j + \frac{\beta^2}{4} \sum_{i \neq j} J_{ij}^2 (1 - m_i^2) (1 - m_j^2) + O(\beta^3).
\end{aligned} \tag{5.38}$$

右边第一项称为平均场变分熵，第二项为平均场变分能量，第三项为 Onsager 反应修正；三项共同构成 SK 模型的 TAP 自由能。

为使自由能最小, 对 $\{m_i\}$ 求导:

$$\frac{\partial[-\beta G_\beta(\mathbf{m})]}{\partial m_i} = -\alpha \tanh m_i + \beta \sum_{j \neq i} J_{ij} m_j - \beta^2 \sum_{j \neq i} J_{ij}^2 (1 - m_j^2) m_i = 0. \quad (5.39)$$

最终得到自洽方程, 即 TAP 方程:

$$m_i = \tanh \left[\beta \sum_{j \neq i} J_{ij} m_j - \beta^2 \sum_{j \neq i} J_{ij}^2 (1 - m_j^2) m_i \right]. \quad (5.40)$$

右边第一项表示局域场的标准平均场近似, 第二项称为 Onsager 反应场, 用于去除自响应的影响 [6]. 若考虑外场 $\{h_i\}$, TAP 方程变为

$$m_i^{t+1} = \tanh \left[\beta h_i + \beta \sum_{j \neq i} J_{ij} m_j^t - \beta^2 \sum_{j \neq i} J_{ij}^2 (1 - (m_j^t)^2) m_i^{t-1} \right], \quad (5.41)$$

这里为迭代设置了正确的时间指标 [7]. 在热力学极限下, 由于 $O(\beta^3)$ 项消失, TAP 近似对 SK 模型变为精确. TAP 不动点是 TAP 自由能的稳定点. 低温下, TAP 方程存在许多 $m_i \neq 0$ 的解, 可解释为稳定或亚稳热力学态 [8, 9].

5.3 TAP 方程的性质

本节研究加入外场后的 TAP 方程 [式 (5.40)] 在自旋玻璃转变点附近的解 [6]. 假定 $i < j$ 时 J_{ij} 是均值为零、方差为 J^2/N 的独立随机变量. 当 $N \rightarrow \infty$ 时可应用大数定律, TAP 方程的 Onsager 项变为

$$\beta^2 \sum_{j \neq i} J_{ij}^2 (1 - m_j^2) m_i = \beta^2 J^2 m_i - \beta^2 \sum_{j \neq i} J_{ij}^2 m_j^2 m_i. \quad (5.42)$$

在自旋玻璃转变点附近, 假定磁化强度 $\{m_i\}$ 很小, 把 TAP 方程右边展开至 $\mathbf{m}$ 的一阶:

$$m_i = \beta \sum_j J_{ij} m_j + \beta h_i - \beta^2 J^2 m_i. \quad (5.43)$$

还假设 h_i 不占主导. 对称矩阵 $\mathbf{J} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T$, 其中 $\mathbf{Q}$ 是正交矩阵, $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_N)$, $\{\lambda_i\}$ 是相互作用矩阵 $\mathbf{J}$ 的特征值. 因而

$$J_{ij} = \sum_n Q_{in} Q_{jn} \lambda_n. \quad (5.44)$$

定义 λ -磁化强度和 λ -场 [6]

$$m_{\lambda_n} = \sum_i Q_{in} m_i, \quad h_{\lambda_n} = \sum_i Q_{in} h_i. \quad (5.45)$$

利用正交条件 $\sum_i Q_{in} Q_{im} = \delta_{nm}$, 有

$$\begin{aligned} \beta \sum_i Q_{in} \sum_j J_{ij} m_j &= \beta \sum_m \lambda_m \sum_i Q_{in} Q_{im} \sum_j Q_{jm} m_j \\ &= \beta \lambda_n m_{\lambda_n}. \end{aligned} \quad (5.46)$$

于是式 (5.43) 可写为

$$m_\lambda = \beta m_\lambda \lambda + \beta h_\lambda - \beta^2 J^2 m_\lambda. \quad (5.47)$$

因此 λ -磁化率为 [10]

$$\chi_\lambda = \frac{\partial m_\lambda}{\partial h_\lambda} = \frac{\beta}{1 - \beta\lambda + (\beta J)^2}. \quad (5.48)$$

随机矩阵 $\mathbf{J}$ 的特征值服从著名的半圆律³[11]:

$$\rho(\lambda) = \frac{\sqrt{4J^2 - \lambda^2}}{2\pi J^2}. \quad (5.49)$$

由式 (5.48) 容易看出, 与最大特征值 $\lambda = 2J$ 对应的磁化率在 $T_g = J$ 处发散, 表明发生连续相变. 该转变位置与复制方法得到的结果 [5] 完全一致.

也可通过计算 Hessian 矩阵来判断顺磁相的稳定性:

$$\mathcal{H}_{ij} = \left. \frac{\partial^2 [\beta G_\beta(\mathbf{m})]}{\partial m_i \partial m_j} \right|_{\mathbf{m}=0} = -\beta J_{ij} + (\beta^2 J^2 + 1)\delta_{ij}. \quad (5.50)$$

稳定性条件是 Hessian 矩阵所有特征值均为正, 由此得到与上文相同的结果. 线性响应理论给出磁化率矩阵 $\chi_{ij} = \partial m_i / \partial h_j$ 与 Hessian 的关系: $(\mathcal{H}^{-1})_{ij} = \beta^{-1} \chi_{ij} = \langle \sigma_i \sigma_j \rangle_c$, 下标 c 表示连通二点关联.

参考文献

- [1] D. J. Thouless, P. W. Anderson, and R. G. Palmer, *Philos. Mag.* 35(3), 593 (1977).
- [2] T. Plefka, *J. Phys. A* 15(6), 1971 (1982).
- [3] A. Georges and J. Yedidia, *J. Phys. A* 24, 2173 (1991).
- [4] A. Maillard, L. Foini, A. L. Castellanos, F. Krzakala, M. Mézard, and L. Zdeborová, *J. Stat. Mech.* 2019(11), 113301 (2019).
- [5] D. Sherrington and S. Kirkpatrick, *Phys. Rev. Lett.* 35(26), 1792 (1975).
- [6] H. Nishimori, *Statistical Physics of Spin Glasses and Information Processing: An Introduction* (Oxford University Press, Oxford, 2001).
- [7] E. Bolthausen, *Commun. Math. Phys.* 325(1), 333 (2014).
- [8] A. Crisanti, L. Leuzzi, G. Parisi, and T. Rizzo, *Phys. Rev. Lett.* 92(12), 127203 (2004).
- [9] T. Aspelmeier, A. J. Bray, and M. A. Moore, *Phys. Rev. Lett.* 92(8), 087203 (2004).
- [10] A. J. Bray and M. A. Moore, *J. Phys. C* 12(11), L441 (1979).
- [11] M. L. Mehta, *Random Matrices* (Academic Press, San Diego, 2004).

³第 17 章将推导此定律.

Nishimori 线

本章介绍广泛自旋玻璃模型中的一个重要概念—Nishimori 线 (Nishimori line), 亦即 Nishimori 温度或约束. 这一概念最初在传统二体相互作用自旋玻璃模型中发现 [1, 2]: 在一个特殊温度下, 复杂玻璃模型的能量可以解析求得, 而复制对称破缺 (RSB) 相 (第 9 章介绍) 不支配基态, 因而底层物理大为简化. 后来, 这一概念又与统计推断问题的 Bayes 最优设定联系起来 [3, 4, 5, 6]. 因而, 它是理解 Bayesian 学习过程的重要理论视角; Bayesian 学习正是深度学习时代最流行的范式之一. 本章先介绍该概念的基础知识, 更多学习理论应用留待后续章节.

6.1 模型设定

西森秀稔最初用于导出特殊温度的模型定义为

$$H = - \sum_{i < j} J_{ij} \sigma_i \sigma_j, \quad (6.1)$$

其中 J_{ij} 是淬火无序. 耦合的分布函数为

$$P(J_{ij}) = p \delta(J_{ij} - J) + (1 - p) \delta(J_{ij} + J), \quad (6.2)$$

其中 p 表示耦合的铁磁偏置, J 是正常数. 每个耦合均从该二项分布中独立生成.

令 $J_{ij} = J \tau_{ij}$, 其中 $\tau_{ij} = \pm 1$. 为方便起见, 引入辅助温度 β_p 参数化原分布 $P(J_{ij})$:

$$P(J_{ij}) = P(\tau_{ij}) = \frac{e^{\beta_p \tau_{ij}}}{2 \cosh \beta_p}, \quad (6.3a)$$

$$\beta_p = \frac{1}{2} \ln \frac{1 - p}{p}. \quad (6.3b)$$

β_p 的这一形式保证两种耦合分布表示等价; 分别代入耦合的两个可能取值即可验证.

6.2 内能的精确结果

根据模型定义, 内能为

$$\begin{aligned} \langle H \rangle_{\tau, \sigma} &= \sum_{\tau} P(\tau) \sum_{\sigma} P(\sigma) \left(-J \sum_{i < j} \tau_{ij} \sigma_i \sigma_j \right) \\ &= \sum_{\tau} \frac{e^{\beta_p \sum_{i < j} \tau_{ij}}}{(2 \cosh \beta_p)^{N_B}} \frac{\sum_{\sigma} e^{\beta J \sum_{i < j} \tau_{ij} \sigma_i \sigma_j} \left(-J \sum_{i < j} \tau_{ij} \sigma_i \sigma_j \right)}{\sum_{\sigma} e^{\beta J \sum_{i < j} \tau_{ij} \sigma_i \sigma_j}}, \end{aligned} \quad (6.4)$$

其中 N_B 为相互作用数（在格点模型中也称为键数）。由于 $\{\tau_{ij}\}$ 相互独立， $P(\boldsymbol{\tau})$ 是因子化的。模型 Hamiltonian 在如下规范变换下不变：

$$\tau_{ij} \longrightarrow \tau_{ij} s_i s_j, \quad (6.5)$$

$$\sigma_i \longrightarrow \sigma_i s_i, \quad (6.6)$$

其中 $\{s_i\}$ 也是 Ising 值构型。将该变换作用于模型内能：

$$\begin{aligned} \langle H \rangle_{\boldsymbol{\tau}, \boldsymbol{\sigma}} &= -\frac{1}{2^N} \sum_{\boldsymbol{\tau}} \frac{\sum_{\boldsymbol{s}} e^{\beta_p \sum_{i<j} \tau_{ij} s_i s_j}}{(2 \cosh \beta_p)^{N_B}} \frac{\sum_{\boldsymbol{\sigma}} e^{\beta J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j} J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j}{\sum_{\boldsymbol{\sigma}} e^{\beta J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j}} \\ &= -\frac{1}{2^N} \sum_{\boldsymbol{\tau}} \frac{Z_{\boldsymbol{s}}}{(2 \cosh \beta_p)^{N_B}} \frac{\sum_{\boldsymbol{\sigma}} e^{\beta J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j} J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j}{Z_{\boldsymbol{\sigma}}}. \end{aligned} \quad (6.7)$$

这里引入 2^N 以抵消对 $\boldsymbol{s}$ 的求和。显然，当 $\beta J = \beta_p$ 时，配分函数 $Z_{\boldsymbol{s}}$ 与 $Z_{\boldsymbol{\sigma}}$ 相消，于是

$$\begin{aligned} \langle H \rangle_{\boldsymbol{\tau}, \boldsymbol{\sigma}} &= -\frac{1}{2^N (2 \cosh \beta_p)^{N_B}} \sum_{\boldsymbol{\tau}, \boldsymbol{\sigma}} e^{\beta J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j} J \sum_{i<j} \tau_{ij} \sigma_i \sigma_j \\ &= -\frac{1}{2^N (2 \cosh \beta_p)^{N_B}} \frac{\partial}{\partial \beta} \sum_{\boldsymbol{\sigma}} \prod_{i<j} \sum_{\tau_{ij}} e^{\beta J \tau_{ij} \sigma_i \sigma_j} \\ &= -N_B J \tanh \beta_p. \end{aligned} \quad (6.8)$$

因此在 Nishimori 温度 $\beta J = \beta_p$ 下，模型内能具有解析表达式；一般情况下内能没有闭式表达。

6.3 Nishimori 线上无 RSB 效应的证明

本节用规范变换证明：在 Nishimori 线 β_p 上，自旋玻璃序参量的分布不具有复杂结构，并且与磁化强度分布严格相同。

磁化强度分布定义为

$$P_m(x; k) = \sum_{\boldsymbol{\tau}} \frac{e^{k_p \sum_{i<j} \tau_{ij}}}{(2 \cosh k_p)^{N_B}} \frac{\sum_{\boldsymbol{\sigma}} e^{k \sum_{i<j} \tau_{ij} \sigma_i \sigma_j} \delta(x - \frac{1}{N} \sum_i \sigma_i)}{\sum_{\boldsymbol{\sigma}} e^{k \sum_{i<j} \tau_{ij} \sigma_i \sigma_j}}, \quad (6.9)$$

其中定义 $k = \beta J$ 、 $k_p = \beta_p$ 。磁化强度分布包含两重平均：对 $\boldsymbol{\sigma}$ 的热平均和对 $\boldsymbol{\tau}$ 的无序平均。二者都是自旋玻璃理论中的标准热力学操作，而无序平均通常很困难。

施加规范变换

$$\tau_{ij} \longrightarrow \tau_{ij} s_i s_j, \quad (6.10)$$

$$\sigma_i \longrightarrow \sigma_i s_i, \quad (6.11)$$

则

$$P_m(x; k) = \frac{1}{2^N} \sum_{\boldsymbol{\tau}, \boldsymbol{s}} \frac{e^{k_p \sum_{i<j} \tau_{ij} s_i s_j}}{(2 \cosh k_p)^{N_B}} \frac{\sum_{\boldsymbol{\sigma}} e^{k \sum_{i<j} \tau_{ij} \sigma_i \sigma_j} \delta(x - \frac{1}{N} \sum_i \sigma_i s_i)}{\sum_{\boldsymbol{\sigma}} e^{k \sum_{i<j} \tau_{ij} \sigma_i \sigma_j}}. \quad (6.12)$$

这一形式还可进一步化简. 经过简单代数整理, 再作第二次规范变换 $\tau_{ij} \rightarrow \tau_{ij}s'_i s'_j$ 、 $\sigma_i \rightarrow \sigma_i s'_i$ 、 $s_i \rightarrow s_i s'_i$, 得到

$$\begin{aligned} P_m(x; k) &= \sum_{\tau} P(\tau) \sum_{\sigma} P(\sigma) \sum_{s} P(s) \delta\left(x - \frac{1}{N} \sum_i \sigma_i s_i\right) \\ &= P_q(x; k, k_p), \end{aligned} \quad (6.13)$$

其中 $P(\sigma)$ 和 $P(s)$ 分别是重标度逆温 k 和 k_p 下的 Boltzmann 测度.

在 Nishimori 温度下, $P_m(x; k_p) = P_q(x; k_p, k_p) = P_q(x; k_p)$. 因此自旋玻璃序参量 (重叠 $q = N^{-1} \sum_i \sigma_i s_i$) 的分布与磁化强度分布具有相同形式. 众所周知, 统计物理中的磁化强度分布很简单, 而重叠分布可能非常复杂, 例如 SK 模型中复制对称破缺效应支配相空间时. Nishimori 线上两个分布的等价性表明, 基态不存在自旋玻璃相. 不过, 描述系统的亚稳 (非平衡) 态时仍可能需要 RSB, 例如文献 [7] 的研究. 总之, 在 Nishimori 线上系统永不进入玻璃相, 支配热力学相始终为复制对称 (RS) 型.

参考文献

- [1] H. Nishimori, J. Phys. C 13(21), 4071 (1980).
- [2] H. Nishimori, Prog. Theor. Phys. 66(4), 1169 (1981).
- [3] Y. Iba, J. Phys. A 32, 3875 (1999).
- [4] L. Zdeborová and F. Krzakala, Adv. Phys. 65(5), 453 (2016).
- [5] H. Huang, J. Stat. Mech. 2017(5), 053302 (2017).
- [6] T. Hou and H. Huang, Phys. Rev. Lett. 124, 248302 (2020).
- [7] M. Yoshida, T. Uezu, T. Tanaka, and M. Okada, J. Phys. Soc. Jpn. 76(5), 054003 (2007).

随机能量模型

本章简要介绍著名的随机能量模型 (random energy model, REM) [1, 2]. 它是 p 自旋相互作用模型的无限体相互作用极限, 但仍能捕捉自旋玻璃的特征 [3]. 这里着重讨论基本概念, 以及它们与其他约束满足问题中常见冻结相的联系, 例如第 13 章将介绍的二值感知机.

7.1 模型设定

考虑 Ising 型自旋, 其相互作用 Hamiltonian 为

$$H(\sigma) = - \sum_{1 \leq i_1 < \dots < i_p \leq N} J_{i_1 \dots i_p} \sigma_{i_1} \dots \sigma_{i_p}, \quad (7.1)$$

耦合服从 Gaussian 分布

$$P(J_{i_1 \dots i_p}) = \sqrt{\frac{N^{p-1}}{\pi J^2 p!}} \exp \left[-\frac{J_{i_1 \dots i_p}^2 N^{p-1}}{J^2 p!} \right], \quad (7.2)$$

其中 $J > 0$, 方差的标度保证广延能量有良好定义. 具有多体相互作用的广义 Hopfield 模型也属于这一类 [4]. 容易验证, 在该标度下 $p = 2$ 对应标准 Sherrington–Kirkpatrick 模型.

我们关心能级 E 的分布, 以判断 $p \rightarrow \infty$ 时它是否变得简单; 一般而言, 该分布可能非常复杂. 根据定义,

$$\begin{aligned} P(E) &= \overline{\delta(E - H(\sigma))} \\ &= \int \frac{d\hat{E}}{2\pi} e^{i\hat{E}E} \prod_{1 \leq i_1 < \dots < i_p \leq N} \overline{e^{i\hat{E}J_{i_1 \dots i_p} \sigma_{i_1} \dots \sigma_{i_p}}}, \end{aligned} \quad (7.3)$$

上横线表示淬火无序平均, 它可以显式算出:

$$\begin{aligned} \overline{e^{i\hat{E}J_{i_1 \dots i_p} \sigma_{i_1} \dots \sigma_{i_p}}} &= \int dJ_{i_1 \dots i_p} P(J_{i_1 \dots i_p}) e^{i\hat{E}J_{i_1 \dots i_p} \sigma_{i_1} \dots \sigma_{i_p}} \\ &= \exp \left[\frac{(i\hat{E}\sigma_{i_1} \dots \sigma_{i_p})^2 J^2 p!}{4N^{p-1}} \right]. \end{aligned} \quad (7.4)$$

当 $N \rightarrow \infty$ 时, 式 (7.3) 中乘积项数可近似为 $N^p/p!$. 最终得到

$$\begin{aligned} P(E) &= \int \frac{d\hat{E}}{2\pi} \exp \left(i\hat{E}E + \frac{(i\hat{E})^2 N J^2}{4} \right) \\ &= \frac{1}{\sqrt{N\pi J^2}} \exp \left(-\frac{E^2}{N J^2} \right), \end{aligned} \quad (7.5)$$

这正是均值为零、涨落量级为 $O(\sqrt{N})$ 的 Gaussian 分布。

p 自旋相互作用模型中能级的 Gaussian 分布本身并不能说明不同能级是否相关。为回答这一问题，推导两个能级 E_1, E_2 的联合分布：

$$\begin{aligned} P(E_1, E_2, q) &= \overline{\delta(E_1 - H(\boldsymbol{\sigma}^1))\delta(E_2 - H(\boldsymbol{\sigma}^2))} \\ &= \iint \frac{d\hat{E}_1 d\hat{E}_2}{4\pi^2} e^{i(\hat{E}_1 E_1 + \hat{E}_2 E_2)} \prod_{i_1 < \dots < i_p} \overline{\exp \left[i\hat{E}_1 J_{i_1 \dots i_p} \sigma_{i_1}^1 \cdots \sigma_{i_p}^1 + i\hat{E}_2 J_{i_1 \dots i_p} \sigma_{i_1}^2 \cdots \sigma_{i_p}^2 \right]}, \end{aligned} \quad (7.6)$$

其中两构型的重叠定义为 $q = N^{-1} \sum_i \sigma_i^1 \sigma_i^2$ 。式 (7.6) 中的无序平均为

$$\begin{aligned} &\overline{\exp \left[i\hat{E}_1 J_{i_1 \dots i_p} \sigma_{i_1}^1 \cdots \sigma_{i_p}^1 + i\hat{E}_2 J_{i_1 \dots i_p} \sigma_{i_1}^2 \cdots \sigma_{i_p}^2 \right]} \\ &= \exp \left\{ \frac{J^2 p!}{4N^{p-1}} \left[(i\hat{E}_1)^2 + (i\hat{E}_2)^2 + 2(i\hat{E}_1)(i\hat{E}_2) \sigma_{i_1}^1 \cdots \sigma_{i_p}^1 \sigma_{i_1}^2 \cdots \sigma_{i_p}^2 \right] \right\}, \end{aligned} \quad (7.7)$$

这里使用自旋取二值 ± 1 的事实。代回式 (7.6)，

$$P(E_1, E_2, q) = \iint \frac{d\hat{E}_1 d\hat{E}_2}{4\pi^2} e^{i(\hat{E}_1 E_1 + \hat{E}_2 E_2)} \exp \left\{ \frac{J^2 N}{4} \left[(i\hat{E}_1)^2 + (i\hat{E}_2)^2 + 2q^p (i\hat{E}_1)(i\hat{E}_2) \right] \right\}. \quad (7.8)$$

最后一步对大 N 使用 $p! \sum_{i_1 < \dots < i_p} \cdots \simeq \sum_{i_1, \dots, i_p} \cdots$ ，并使用重叠定义。算出式 (7.8) 中的 Gaussian 积分，得到由 q, J 参数化的联合分布

$$\begin{aligned} P(E_1, E_2, q) &= \frac{1}{\pi J^2 N \sqrt{1 - q^{2p}}} \exp \left[\frac{2E_1 E_2 q^p - E_1^2 - E_2^2}{J^2 N (1 - q^{2p})} \right] \\ &= [N\pi J^2 (1 + q^p) N\pi J^2 (1 - q^p)]^{-1/2} \\ &\quad \times \exp \left[-\frac{(E_1 + E_2)^2}{2J^2 N (1 + q^p)} - \frac{(E_1 - E_2)^2}{2J^2 N (1 - q^p)} \right]. \end{aligned} \quad (7.9)$$

若 $|q| < 1$ ，则立刻有 $P(E_1, E_2, q) \xrightarrow{p \rightarrow \infty} P(E_1)P(E_2)$ ，其中 $P(E_1)$ 和 $P(E_2)$ 是前面导出的 Gaussian 分布。这表明不同能级不相关，且各自严格服从该 Gaussian 分布。

7.2 相图

上述数学结果给出了无限体相互作用模型的简洁物理图像。可直接计算具有预定能级 E 的典型构型数：

$$\langle n(E) \rangle = 2^N P(E) = \frac{1}{\sqrt{\pi N J^2}} \exp \left\{ N \left[\ln 2 - \left(\frac{E}{NJ} \right)^2 \right] \right\}. \quad (7.10)$$

由此得到临界能级 $E_0 = NJ\sqrt{\ln 2}$ ；当 $|E| > E_0$ 时不存在构型，而当 $|E| < E_0$ 时，相应能级具有指数多个构型。在热力学极限下，临界能级以下的每自旋熵密度为

$$s(E) = \lim_{N \rightarrow \infty} \frac{\ln \langle n(E) \rangle}{N} = \ln 2 - \left(\frac{\epsilon}{J} \right)^2,$$

其中 $\epsilon = E/N$ 是能量密度. 由热力学关系 $dS/dE = 1/T$, 还可得到 $\epsilon = -J^2/(2T)$, 并由熵消失的条件确定临界温度 $T_c = J/(2\sqrt{\ln 2})$.

最终, 随机能量模型的平衡性质由自由能曲线 $F = E - TS$ 总结:

$$\frac{F}{N} = \begin{cases} -T \ln 2 - \frac{J^2}{4T}, & T > T_c, \\ -J\sqrt{\ln 2}, & T < T_c \end{cases} \quad (7.11)$$

这意味着临界温度以下系统自由能不再依赖温度, 因为离散自由度系统的熵消失. 熵消失表明系统进入冻结玻璃相; 在热力学意义上, 该转变是连续的 (没有潜热). Gallager 码 [5, 6] 和二值感知机 [7, 8, 9] 中也发现了这种冻结玻璃相. 最后指出, 一步复制对称破缺 (见第 9 章) 对随机能量模型是精确的 [3].

参考文献

- [1] B. Derrida, Phys. Rev. Lett. 45, 79 (1980).
- [2] B. Derrida, Phys. Rev. B 24(5), 2613 (1981).
- [3] D. Gross and M. Mézard, Nucl. Phys. B 240(4), 431 (1984).
- [4] E. Gardner, J. Phys. A 20(11), 3453 (1987).
- [5] A. Montanari, Eur. Phys. J. B 23(1), 121 (2001).
- [6] H. Huang, Commun. Theor. Phys. 63(1), 115 (2015).
- [7] W. Krauth and M. Mézard, J. Phys. 50(20), 3057 (1989).
- [8] H. Huang and Y. Kabashima, Phys. Rev. E 90, 052813 (2014).
- [9] H. Huang, K. Y. M. Wong, and Y. Kabashima, J. Phys. A 46, 375002 (2013).

Hopfield 模型的统计力学理论

Hopfield 模型是著名的脑内联想记忆抽象模型 [1, 2]. Amit、Gutfreund 与 Sompolinsky 在奠基性论文 [3] 中首次分析了它的平衡性质. 为得到相图, 他们采用了最初在自旋玻璃理论中发展的复制方法; 此后该方法在神经网络研究中广泛流行. 这项工作还开创了一门新学科—计算/理论神经科学, 它是本世纪全球脑计划的重要分支. 本章将深入应用复制技巧 [4], 详细介绍该模型的物理, 包括联想记忆中的相变.

8.1 Hopfield 模型

在 Hopfield 网络中, 所有神经元都通过实值权重彼此相连 (见图 8.1). 可按 Hebb 方式给权重 w_{ij} 赋值, 从而把随机生成的模式存入网络; 所谓 Hebb 方式, 即“共同激发的细胞连接在一起”. 所有权重赋值后, 若向网络输入一个受扰模式, 网络动力学可通过局域更新神经状态收敛到正确的未受扰模式.




图 8.1: Hopfield 网络的典型结构. 圆表示神经元, 带箭头的连线表示两神经元间的对称权重 ($w_{ij} = w_{ji}$). 每个神经元都与其他所有神经元相连.

Hopfield 模型中, 神经元 i 在时刻 t 的状态取二值 ± 1 :

$$S_i(t) = \begin{cases} -1, & \text{非活动,} \\ 1, & \text{活动.} \end{cases} \quad (8.1)$$

更新规则为

$$S_i(t+1) \leftarrow \text{sgn} \left(\sum_j w_{ij} S_j(t) - \theta_i \right), \quad (8.2)$$

其中

$$\text{sgn}(x) = \begin{cases} 1, & x > 0, \\ 0, & x = 0, \\ -1, & x < 0, \end{cases}$$

θ_i 是神经元 S_i 的激发偏置. 实际上, 该规则就是模型的零温 Monte Carlo 动力学.

现在需恰当选择 $\{w_{ij}\}$, 以保证二值模式 $\{\xi^{(\mu)}\}$ 是吸引子. 若给网络输入接近某一存储模式 (例如 $\xi^{(\nu)}$) 的 $S(t=0)$, 则期望网络收敛到 $\xi^{(\nu)}$.

先考虑网络只存储一个模式 $\xi^{(1)}$ 的简单设定. 可按 Hebb 规则选择权重

$$w_{ij} = \frac{1}{N} \xi_i^{(1)} \xi_j^{(1)}, \quad (8.3)$$

其中 $i \neq j$ 、 $\theta_i = 0$, 且通常对所有 i 令 $w_{ii} = 0$. 为检验该规则, 把模式 $\xi^{(1)}$ 输入网络:

$$\sum_{j=1}^N w_{ij} \xi_j^{(1)} = \frac{1}{N} \sum_{j=1}^N \xi_i^{(1)} \xi_j^{(1)} \xi_j^{(1)} = \frac{1}{N} \sum_{j=1}^N \xi_i^{(1)} = \xi_i^{(1)}. \quad (8.4)$$

因此

$$\text{sgn} \left(\sum_{j=1}^N w_{ij} \xi_j^{(1)} \right) = \xi_i^{(1)} \implies \mathbf{S}(t > 0) = \xi^{(1)}. \quad (8.5)$$

若把反向模式 $-\xi^{(1)}$ 输入网络, 则

$$\text{sgn} \left(- \sum_{j=1}^N w_{ij} \xi_j^{(1)} \right) = -\xi_i^{(1)} \implies \mathbf{S}(t > 0) = -\xi^{(1)}. \quad (8.6)$$

因此若 $\xi^{(1)}$ 是吸引子, 则 $-\xi^{(1)}$ 也是吸引子. 写出 Hamiltonian 后可见, 这是 Hopfield 模型的一般性质.

平衡统计物理中的 Hamiltonian (能量函数) 定义为

$$H = -\frac{1}{2} \sum_{i,j} w_{ij} S_i S_j, \quad (8.7)$$

其中 $w_{ij} = N^{-1} \sum_{\mu=1}^P \xi_i^\mu \xi_j^\mu$ 是对称的, 从而保证平衡态存在. 模式分量彼此独立, 取值分布为 $P(\xi_i^\mu = \pm 1) = 1/2$. 在模型的零温动力学下, Hamiltonian H 保持不变或减小. 为说明这一点, 忽略激发偏置并考虑更新

$$S'_k = \text{sgn} \left(\sum_j w_{kj} S_j \right). \quad (8.8)$$




图 8.2: Hopfield 网络的能量景观. 能量函数的极小值是状态空间中的吸引子, 但并非每个吸引子都对应存储模式. 这些亚稳态称为伪记忆, 例如若干存储模式的线性组合 [5].

于是要么 $S'_k = S_k$, 要么 $S'_k = -S_k$. 第一种情况下 H 不变; 第二种情况下

$$H' - H = \sum_{j \neq k} w_{kj} S_k S_j + \sum_{i \neq k} w_{ik} S_i S_k = 2 \sum_{j \neq k} w_{kj} S_k S_j. \quad (8.9)$$

因为 $\sum_j w_{kj} S_j$ 的符号与 S'_k 相同, 而 $S'_k = -S_k$, 所以

$$H' - H < 0. \quad (8.10)$$

因此每一步更新中, H 要么不变, 要么减小. 经过足够多次更新, 能量函数落入某个极小值, 期望它对应一个存储模式 (图 8.2). 可在 Hopfield 模型的 Hamiltonian 上实现零温 Monte Carlo 抽样, 以交叉检验该推导.

8.2 复制方法

在热力学极限下, 自由能具有自平均性质, 即 $-\beta f = \langle \ln Z \rangle$, 其中 Z 是配分函数. 随着自由度增加, 单个样本的自由能将尖锐地收敛到淬火平均值. 然而, 淬火平均 $\langle \ln Z \rangle$ 难以直接计算, 而退火平均 $\langle Z \rangle$ 容易得多. 在大多数感兴趣的情形下, $\langle \ln Z \rangle \neq \ln \langle Z \rangle$; 由 Jensen 不等式, 退火平均实际给出淬火平均的上界.

复制技巧 (replica trick) 通过引入原系统的多个副本来变换这一计算. 原来的相互作用系统可解耦为一个考虑副本间相关性的等价系统, 从而大幅简化困难的计算. 数学上,

$$\ln Z = \lim_{n \rightarrow 0} \frac{Z^n - 1}{n}. \quad (8.11)$$

于是

$$\langle \ln Z \rangle = \lim_{n \rightarrow 0} \frac{\langle Z^n \rangle - 1}{n} = \lim_{n \rightarrow 0} \frac{\ln \langle Z^n \rangle}{n}, \quad (8.12)$$

其中 $\langle \cdot \rangle$ 表示对 ξ 的无序平均. 由于 $Z^n \simeq 1 + n \ln Z + \dots$, 有 $\langle Z^n \rangle \simeq 1 + n \langle \ln Z \rangle + \dots$. 因而

$$\lim_{n \rightarrow 0} \frac{\ln \langle Z^n \rangle}{n} = \lim_{n \rightarrow 0} \frac{\ln[1 + n \langle \ln Z \rangle]}{n} = \langle \ln Z \rangle. \quad (8.13)$$

每自旋平均自由能可由

$$f = \lim_{n \rightarrow 0} \lim_{N \rightarrow \infty} \frac{-\ln \langle Z^n \rangle}{\beta n N} \quad (8.14)$$

计算.

先假定幂次 n 为整数; 算出 $\langle Z^n \rangle$ 后, 再取 $n \rightarrow 0$ 的极限. 这一操作在物理上难以理解, 因此结果必须与模型的物理模拟比较. 在这个意义上, 腔近似比复制技巧更具物理透明性; 不过在大多数情形 (是否所有情形都适用尚不确定) 中, 两种方法给出相同结果. 为在热力学极限使用 Laplace 方法, 式 (8.14) 还交换了 $n \rightarrow 0$ 与 $N \rightarrow \infty$ 两个极限的次序, 这也并非数学严格的操作. 但最终结果通常与物理直觉和数值模拟相符.

现在假设网络能存储 $P = \alpha N$ 个随机模式, 其中 α 是记忆负载. 注意 $H = -\frac{1}{2} \sum_{i,j}^N w_{ij} S_i S_j$, 且 $w_{ij} = N^{-1} \sum_{\mu=1}^P \xi_i^\mu \xi_j^\mu$. 因而

$$\begin{aligned} \langle Z^n \rangle &= \text{Tr} \left\langle \exp \left[\frac{\beta}{2N} \sum_{i,j} \sum_{\mu=1}^P \sum_{\rho=1}^n \xi_i^\mu \xi_j^\mu S_i^\rho S_j^\rho \right] \right\rangle \\ &= \text{Tr} \left\langle \prod_{\rho,\mu} \exp \left[\frac{\beta N}{2} \left(\frac{1}{N} \sum_i \xi_i^\mu S_i^\rho \right)^2 \right] \right\rangle, \end{aligned} \quad (8.15)$$

其中 Tr 表示对全部构型 $\{\mathbf{S}\}$ 求和, $\langle \cdot \rangle$ 表示对随机模式的淬火无序平均.

为线性化二次项, 使用 Gaussian 积分

$$e^{ab^2} = \sqrt{\frac{a}{\pi}} \int e^{-ax^2 + 2abx} dx, \quad (8.16)$$

并作代换

$$b \rightarrow \frac{1}{N} \sum_i \xi_i^\mu S_i^\rho, \quad x \rightarrow m_\rho^\mu, \quad a \rightarrow \frac{\beta N}{2}. \quad (8.17)$$

自然地引入对 m_ρ^μ 的积分:

$$\begin{aligned} \langle Z^n \rangle &= \text{Tr} \left\langle \int \prod_{\rho,\mu} \left(\sqrt{\frac{\beta N}{2\pi}} dm_\rho^\mu \right) \exp \left[-\frac{\beta N}{2} \sum_{\rho,\mu} (m_\rho^\mu)^2 + \beta \sum_{\rho,\mu} m_\rho^\mu \sum_i \xi_i^\mu S_i^\rho \right] \right\rangle \\ &= \text{Tr} \left\langle \int \prod_{\rho,\mu} dm_\rho^\mu \exp \left[-\frac{\beta N}{2} \sum_{\mu \geq 2, \rho} (m_\rho^\mu)^2 + \beta \sum_{\mu \geq 2, \rho} m_\rho^\mu \sum_i \xi_i^\mu S_i^\rho \right. \right. \\ &\quad \left. \left. - \frac{\beta N}{2} \sum_\rho (m_\rho^1)^2 + \beta \sum_\rho m_\rho^1 \sum_i \xi_i^1 S_i^\rho \right] \right\rangle, \end{aligned} \quad (8.18)$$

其中省略了不影响后续的归一化因子，并把第一个模式与其他模式分开。

进一步假定只提取第一个模式 $\mu = 1$ ，因而其重叠 $m_\rho^1 \sim O(1)$ 。对未提取模式 $\mu \geq 2$ ，因为 $\langle \sum_i \xi_i^\mu S_i^\rho \rangle_\xi = 0$ ，且 $\langle (\sum_i \xi_i^\mu S_i^\rho)^2 \rangle_\xi = N$ ，所以

$$m_\rho^\mu = \frac{1}{N} \sum_i \xi_i^\mu S_i^\rho \simeq O(N^{-1/2}), \quad \mu \geq 2. \quad (8.19)$$

为使用 $O(1)$ 的 m_ρ^μ ，对未提取模式作重标度 $m_\rho^\mu \rightarrow m_\rho^\mu / \sqrt{\beta N}$ ，得到

$$\begin{aligned} \langle Z^n \rangle \propto \text{Tr} \int \prod_{\rho, \mu > 1} dm_\rho^\mu \prod_\rho dm_\rho^1 \exp \left[-\frac{1}{2} \sum_{\mu \geq 2, \rho} (m_\rho^\mu)^2 + \sqrt{\frac{\beta}{N}} \sum_{\mu \geq 2, \rho} m_\rho^\mu \sum_i \xi_i^\mu S_i^\rho \right. \\ \left. - \frac{\beta N}{2} \sum_\rho (m_\rho^1)^2 + \beta \sum_\rho m_\rho^1 \sum_i \xi_i^1 S_i^\rho \right]. \end{aligned} \quad (8.20)$$

对涉及未凝聚模式 $\mu \geq 2$ 的部分，

$$\begin{aligned} & \left\langle \exp \left[\sqrt{\frac{\beta}{N}} \sum_{\mu \geq 2, \rho} m_\rho^\mu \sum_i \xi_i^\mu S_i^\rho \right] \right\rangle_{\{\xi_i^\mu: \mu > 1\}} \\ & \propto \exp \left[\sum_{\mu \geq 2, i} \ln \cosh \left(\sqrt{\frac{\beta}{N}} \sum_\rho m_\rho^\mu S_i^\rho \right) \right] \\ & \simeq \exp \left[\sum_{\mu \geq 2, i} \frac{\beta}{2N} \left(\sum_\rho m_\rho^\mu S_i^\rho \right)^2 \right]. \end{aligned} \quad (8.21)$$

这里使用 $\langle e^{A\xi} \rangle_{\xi=\pm 1} = \cosh A$ （与构型无关的常数略去）以及 $\ln \cosh x = x^2/2 + \dots$ 的小 x 展开。

写出

$$\sum_\rho (m_\rho^\mu)^2 = \sum_{\rho, \sigma} m_\rho^\mu \delta_{\rho\sigma} m_\sigma^\mu, \quad (8.22)$$

$$\frac{1}{N} \sum_i \left(\sum_\rho m_\rho^\mu S_i^\rho \right)^2 = \sum_{\rho, \sigma} m_\rho^\mu \left(\frac{1}{N} \sum_i S_i^\rho S_i^\sigma \right) m_\sigma^\mu \equiv \sum_{\rho, \sigma} m_\rho^\mu q_{\rho\sigma} m_\sigma^\mu. \quad (8.23)$$

进一步定义

$$\kappa_{\rho\sigma} = \delta_{\rho\sigma} - \frac{\beta}{N} \sum_i S_i^\rho S_i^\sigma \equiv \delta_{\rho\sigma} - \beta q_{\rho\sigma}, \quad (8.24)$$

$$\mathbf{K} = \mathbf{I} - \beta \mathbf{Q}, \quad (8.25)$$

其中

$$q_{\rho\sigma} = \begin{cases} N^{-1} \sum_i S_i^\rho S_i^\sigma, & \rho \neq \sigma, \\ 1, & \rho = \sigma, \end{cases} \quad (8.26)$$

$\mathbf{K}, \mathbf{Q}$ 是元素分别为 $\kappa_{\rho\sigma}, q_{\rho\sigma}$ 的对称 $n \times n$ 矩阵, $\mathbf{I}$ 是单位矩阵.

用 Dirac delta 函数的积分表示引入 $q_{\rho\sigma}$, 得到

$$\begin{aligned} \langle Z^n \rangle &\propto \text{Tr} \int \prod_{\rho, \sigma} dq_{\rho\sigma} \delta \left(q_{\rho\sigma} - \frac{1}{N} \sum_i S_i^\rho S_i^\sigma \right) \prod_{\mu \geq 2, \rho} dm_\rho^\mu \\ &\times \exp \left[-\frac{1}{2} \sum_{\mu \geq 2} \sum_{\rho, \sigma} m_\rho^\mu \kappa_{\rho\sigma} m_\sigma^\mu \right] \\ &\times \int \prod_{\rho} dm_\rho^1 \exp \left[-\frac{\beta N}{2} \sum_{\rho} (m_\rho^1)^2 + \beta \sum_{\rho} m_\rho^1 \sum_i \xi_i^1 S_i^\rho \right]. \end{aligned} \quad (8.27)$$

使用多元 Gaussian 积分

$$\int_{\mathbb{R}^n} d\mathbf{m} e^{-\mathbf{m}^\top \mathbf{K} \mathbf{m}} = \sqrt{\frac{\pi^n}{\det \mathbf{K}}}, \quad (8.28)$$

可得

$$\int \prod_{\mu \geq 2, \rho} dm_\rho^\mu \exp \left[-\frac{1}{2} \sum_{\mu \geq 2} \sum_{\rho, \sigma} m_\rho^\mu \kappa_{\rho\sigma} m_\sigma^\mu \right] = \frac{C}{(\det \mathbf{K})^{(P-1)/2}}, \quad (8.29)$$

其中 C 为常数. 由于 $\det(e^{\mathbf{K}}) = e^{\text{Tr} \mathbf{K}}$ 以及 $\det \mathbf{K} = e^{\text{Tr} \ln \mathbf{K}}$,

$$(\det \mathbf{K})^{-(P-1)/2} = \exp \left[-\frac{P-1}{2} \text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) \right]. \quad (8.30)$$

使用 Dirac delta 函数的 Fourier 表示

$$\delta(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ikx} dk, \quad (8.31)$$

并重标度共轭参数 $r_{\rho\sigma}$, 得到

$$\text{Tr} \int \prod_{\rho} dm_\rho^1 \prod_{\rho, \sigma} dq_{\rho\sigma} dr_{\rho\sigma} \exp \left[-\frac{N\alpha\beta^2}{2} \sum_{\rho, \sigma} r_{\rho\sigma} q_{\rho\sigma} + \frac{\alpha\beta^2}{2} \sum_{i, \rho, \sigma} r_{\rho\sigma} S_i^\rho S_i^\sigma \right] \mathcal{I}, \quad (8.32)$$

其中 $\mathcal{I}$ 表示式 (8.27) 中未显示的其他部分, 并使用 $\alpha = P/N$.

依赖 S_i 的部分可写为

$$\begin{aligned} &\left\langle \text{Tr} \exp \left[\beta \sum_{\rho} m_\rho^1 \sum_i \xi_i^1 S_i^\rho + \frac{\alpha\beta^2}{2} \sum_{i, \rho, \sigma} r_{\rho\sigma} S_i^\rho S_i^\sigma \right] \right\rangle_{\xi^1} \\ &= \exp \left\{ N \langle \ln \text{Tr} e^{\beta H_{\xi^1}} \rangle_{\xi^1} \right\}, \end{aligned} \quad (8.33)$$

其中利用随机模式独立同分布这一事实, 以对模式构型的平均取代对 i 的求和, 并定义

$$\beta H_{\xi^1} = \frac{\alpha\beta^2}{2} \sum_{\rho, \sigma} r_{\rho\sigma} S^\rho S^\sigma + \beta \sum_{\rho} m_\rho^1 \xi^1 S^\rho. \quad (8.34)$$

这里的 ξ^1 只是随机模式向量的一个典型分量.

最终,

$$\begin{aligned} \langle Z^n \rangle \propto & \int \prod_{\rho} dm_{\rho}^1 \prod_{\rho, \sigma} dq_{\rho\sigma} dr_{\rho\sigma} \exp \left[-\frac{N\alpha\beta^2}{2} \sum_{\rho, \sigma} r_{\rho\sigma} q_{\rho\sigma} \right] \\ & \times \exp \left[-\frac{P-1}{2} \text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) \right] \\ & \times \exp \left[-\frac{\beta N}{2} \sum_{\rho} (m_{\rho}^1)^2 + N \langle \ln \text{Tr} e^{\beta H_{\xi^1}} \rangle_{\xi^1} \right]. \end{aligned} \quad (8.35)$$

当 N 足够大时, 可使用 Laplace 方法

$$\int_a^b e^{Nf(z)} dz \simeq \sqrt{\frac{2\pi}{-Nf''(z_0)}} e^{Nf(z_0)}, \quad (8.36)$$

其中 z_0 是极大值点. 因而 $\langle Z^n \rangle \sim e^{NF(\theta^*)}$, $F(\theta^*) = \max_{\theta} F(\theta)$, θ 表示模型的序参量集合. 淬火无序平均自由能为

$$\langle \ln Z \rangle = \lim_{n \rightarrow 0} \frac{\ln \langle Z^n \rangle}{n} = N \lim_{n \rightarrow 0} \frac{F(\theta^*)}{n}, \quad (8.37)$$

其中

$$\begin{aligned} F(\{r_{\rho\sigma}, q_{\rho\sigma}, m_{\rho}^1\}) = & -\frac{\alpha\beta^2}{2} \sum_{\rho, \sigma} r_{\rho\sigma} q_{\rho\sigma} - \frac{\alpha}{2} \text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) \\ & - \frac{\beta}{2} \sum_{\rho} (m_{\rho}^1)^2 + \langle \ln \text{Tr} e^{\beta H_{\xi^1}} \rangle_{\xi^1}. \end{aligned} \quad (8.38)$$

这里对大 N 使用 $P-1 \simeq P = \alpha N$. $(r_{\rho\sigma}, q_{\rho\sigma}, m_{\rho}^1)$ 构成模型的序参量集合, 其物理含义如下.

首先对 $q_{\rho\sigma}$ 求导. 保留式 (8.27) 中对 $\{m_{\rho}^{\mu}\}$ 的积分并将磁化强度重标度回去, 稳定条件为

$$\frac{\partial F}{\partial q_{\rho\sigma}} = 0 \implies \frac{\partial}{\partial q_{\rho\sigma}} \left[-\frac{N\alpha\beta^2}{2} \sum_{\rho, \sigma} r_{\rho\sigma} q_{\rho\sigma} + \frac{\beta}{2} (\beta N)^2 \sum_{\mu \geq 2, \rho, \sigma} m_{\rho}^{\mu} q_{\rho\sigma} m_{\sigma}^{\mu} \right] = 0, \quad (8.39)$$

从而得到共轭序参量

$$r_{\rho\sigma} = \frac{1}{\alpha} \sum_{\mu \geq 2} m_{\rho}^{\mu} m_{\sigma}^{\mu}. \quad (8.40)$$

因此 $r_{\rho\sigma}$ 可理解为未凝聚模式效应之和 (这里只有一个被提取模式).

其次对 m_{ρ}^{μ} 求导 [见式 (8.20)]:

$$\frac{\partial F}{\partial m_{\rho}^{\mu}} = 0 \implies \frac{\partial}{\partial m_{\rho}^{\mu}} \left[-\frac{\beta N}{2} (m_{\rho}^{\mu})^2 + \beta m_{\rho}^{\mu} \sum_i \xi_i^{\mu} S_i^{\rho} \right] = 0, \quad (8.41)$$

得到

$$m_\rho^\mu = \frac{1}{N} \sum_i \xi_i^\mu S_i^\rho. \quad (8.42)$$

m_ρ^μ 正是系统状态与第 μ 个模式的重叠，刻画记忆提取质量。

最后，由自由能的稳定性条件 [见式 (8.32)]

$$\frac{\partial F}{\partial r_{\rho\sigma}} = 0 \implies \frac{\partial}{\partial r_{\rho\sigma}} \left[-\frac{N\alpha\beta^2}{2} \sum_{\rho,\sigma} r_{\rho\sigma} q_{\rho\sigma} + \frac{\alpha\beta^2}{2} \sum_{i,\rho,\sigma} r_{\rho\sigma} S_i^\rho S_i^\sigma \right] = 0, \quad (8.43)$$

得到 Edwards–Anderson 序参量

$$q_{\rho\sigma} = \frac{1}{N} \sum_i S_i^\rho S_i^\sigma. \quad (8.44)$$

一般而言， $q_{\rho\sigma}$ 是两个纯态的相互重叠；若单个态支配相空间，则 Edwards–Anderson 序参量刻画该态的大小。

8.2.1 复制对称设定

继续推导需要对重叠矩阵作近似。取最简单的形式，即重叠在副本指标的置换下不变，称为复制对称 (replica symmetry, RS) 设定：

$$r_{\rho\sigma} = r \quad \forall \rho, \sigma, \quad m_\rho^1 = m \quad \forall \rho, \quad q_{\rho\sigma} = q \quad \forall \rho \neq \sigma. \quad (8.45)$$

于是

$$\begin{aligned} F(r, q, m) = & -\frac{\alpha\beta^2}{2} r q (n^2 - n) - \frac{\alpha\beta^2}{2} n r - \frac{\alpha}{2} \text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) \\ & - \frac{\beta}{2} n m^2 + \langle \ln \text{Tr} e^{\beta H_{\xi^1}} \rangle_{\xi^1}, \end{aligned} \quad (8.46)$$

且

$$\begin{aligned} \langle \ln Z \rangle = & \frac{N\alpha\beta^2}{2} r (q - 1) - \frac{\alpha N}{2} \lim_{n \rightarrow 0} \frac{\text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q})}{n} - \frac{\beta N}{2} m^2 \\ & + N \lim_{n \rightarrow 0} \frac{\langle \ln \text{Tr} e^{\beta H_{\xi^1}} \rangle_{\xi^1}}{n}, \end{aligned} \quad (8.47)$$

其中

$$\beta H_{\xi^1} = \beta m \xi^1 \sum_\rho S^\rho + \frac{\alpha\beta^2 r}{2} \sum_{\rho,\sigma} S^\rho S^\sigma. \quad (8.48)$$

先计算式 (8.47) 最后一项。利用 Gaussian 积分线性化副本和的平方：

$$\begin{aligned} \text{Tr} e^{\beta H_{\xi^1}} &= \text{Tr} \exp \left[\beta m \xi^1 \sum_\rho S^\rho + \frac{\alpha\beta^2 r}{2} \left(\sum_\rho S^\rho \right)^2 \right] \\ &= \int Dz \left[2 \cosh(\beta \sqrt{\alpha r} z + \beta m \xi^1) \right]^n, \quad Dz \equiv \frac{e^{-z^2/2}}{\sqrt{2\pi}} dz. \end{aligned} \quad (8.49)$$

因此

$$\lim_{n \rightarrow 0} \text{Tr} e^{\beta H_{\xi^1}} = \int Dz = 1. \quad (8.50)$$

对 n 求导可算出所需极限：

$$\lim_{n \rightarrow 0} \frac{\ln \text{Tr} e^{\beta H_{\xi^1}}}{n} = \int Dz \ln [2 \cosh(\beta \sqrt{\alpha r} z + \beta m \xi^1)]. \quad (8.51)$$

接着计算式 (8.47) 的矩阵迹项. 因 $\mathbf{Q}$ 为对称矩阵, 可对角化:

$$\mathbf{A} \mathbf{Q} \mathbf{A}^{-1} = \mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n). \quad (8.52)$$

把 $\ln(\mathbf{I} - \beta \mathbf{Q})$ 展为 $\mathbf{Q}$ 的幂级数,

$$\text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) = -\text{Tr} \sum_{\ell=1}^{\infty} \frac{\beta^\ell (\mathbf{A} \mathbf{Q} \mathbf{A}^{-1})^\ell}{\ell} = \sum_{i=1}^n \ln(1 - \beta \lambda_i). \quad (8.53)$$

这等价于正定矩阵的恒等式 $\text{Tr} \ln \mathbf{K} = \ln \det \mathbf{K}$.

$\mathbf{Q}$ 的特征方程为

$$\begin{aligned} \det(\mathbf{Q} - \lambda \mathbf{I}) &= \begin{vmatrix} 1 - \lambda & q & \cdots & q \\ q & 1 - \lambda & \cdots & q \\ \vdots & \vdots & \ddots & \vdots \\ q & q & \cdots & 1 - \lambda \end{vmatrix} \\ &= [1 - \lambda + (n - 1)q](1 - q - \lambda)^{n-1} = 0. \end{aligned} \quad (8.54)$$

因此 $\mathbf{Q}$ 有一个特征值 $1 + (n - 1)q$, 以及 $n - 1$ 个特征值 $1 - q$. 于是

$$\text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q}) = \ln(1 - \beta + \beta q - n\beta q) + (n - 1) \ln(1 - \beta + \beta q), \quad (8.55)$$

并由 L'Hospital 法则得到

$$\lim_{n \rightarrow 0} \frac{\text{Tr} \ln(\mathbf{I} - \beta \mathbf{Q})}{n} = -\frac{\beta q}{1 - \beta + \beta q} + \ln(1 - \beta + \beta q). \quad (8.56)$$

合并各项, Hopfield 模型的自由能为

$$\begin{aligned} -\beta f &= \frac{\alpha \beta^2}{2} r(q - 1) - \frac{\alpha}{2} \left[\ln(1 - \beta + \beta q) + \frac{\beta q}{1 - \beta + \beta q} \right] - \frac{\beta}{2} m^2 \\ &\quad + \int Dz \langle \ln [2 \cosh(\beta \sqrt{\alpha r} z + \beta m \xi^1)] \rangle_{\xi^1}. \end{aligned} \quad (8.57)$$

为完成 Laplace 方法, 对 RS 设定中的所有序参量求导, 得到鞍点条件

$$\frac{\partial(-\beta f)}{\partial r} = 0, \quad \frac{\partial(-\beta f)}{\partial m} = 0, \quad \frac{\partial(-\beta f)}{\partial q} = 0. \quad (8.58)$$

例如，对 r 求导并分部积分：

$$\begin{aligned}
q &= -\frac{1}{\beta\sqrt{\alpha r}} \int Dz z \langle \tanh(\beta\sqrt{\alpha r} z + \beta m \xi^1) \rangle_{\xi^1} + 1 \\
&= \int Dz \langle \tanh^2(\beta\sqrt{\alpha r} z + \beta m \xi^1) \rangle_{\xi^1} \\
&= \int Dz \tanh^2[\beta(\sqrt{\alpha r} z + m)].
\end{aligned} \tag{8.59}$$

类似地计算 r, m ，得到联想记忆模型的鞍点方程：

$$q = \int Dz \tanh^2[\beta(\sqrt{\alpha r} z + m)], \tag{8.60}$$

$$m = \int Dz \langle \xi \tanh[\beta(\sqrt{\alpha r} z + m \xi)] \rangle_{\xi} = \int Dz \tanh[\beta(\sqrt{\alpha r} z + m)], \tag{8.61}$$

$$r = \frac{q}{(1 - \beta + \beta q)^2}. \tag{8.62}$$

通过分析这些方程以及相应自由能函数的行为，即可推断相变。

8.2.2 零温极限

在复制对称假定下，当 $T \rightarrow 0$ ($\beta \rightarrow \infty$) 时，

$$\tanh(\beta x) \longrightarrow \text{sign}(x) = \begin{cases} 1, & x > 0, \\ 0, & x = 0, \\ -1, & x < 0. \end{cases} \tag{8.63}$$

式 (8.61) 变为

$$\begin{aligned}
m &= \int Dz \text{sign}(\sqrt{\alpha r} z + m) + O(T) \\
&= \text{erf}\left(\frac{m}{\sqrt{2\alpha r}}\right) + O(T).
\end{aligned} \tag{8.64}$$

另一方面， $\beta \rightarrow \infty$ 时

$$\begin{aligned}
1 - q &= \int \frac{dz}{\sqrt{2\pi}} e^{-z^2/2} [1 - \tanh^2 \beta(\sqrt{\alpha r} z + m)] \\
&\simeq \frac{1}{\sqrt{2\pi}} e^{-m^2/(2\alpha r)} \frac{1}{\beta\sqrt{\alpha r}} \int dz \frac{\partial}{\partial z} \tanh \beta(\sqrt{\alpha r} z + m) \\
&= \sqrt{\frac{2}{\pi}} \frac{1}{\beta\sqrt{\alpha r}} e^{-m^2/(2\alpha r)}.
\end{aligned} \tag{8.65}$$

式 (8.60) 因而给出 $q = 1 - CT$ ，其中

$$C \equiv \sqrt{\frac{2}{\pi r \alpha}} \exp\left(-\frac{m^2}{2\alpha r}\right). \tag{8.66}$$

利用这些中间结果，式 (8.62) 变为 $r = (1 - C)^{-2}$.

定义辅助变量 $y = m/\sqrt{2\alpha r}$ ，可把 m, r 的方程约化为一个方程：

$$\operatorname{erf}(y) = y \left[2\sqrt{2\alpha} + \frac{2}{\sqrt{\pi}} e^{-y^2} \right]. \quad (8.67)$$

一个解为 $y = m = 0$ ，即自旋玻璃 (SG) 解. 当 $\alpha \geq \alpha_c = 0.138$ 时，这是唯一解；当 $\alpha < \alpha_c$ 时出现 $m \neq 0$ 的铁磁解. 由于模型的对称性，这样的解共有 $2P$ 个. 在 $\alpha = \alpha_c$ 时，重叠为 $m = 0.967$ [6].




图 8.3: $T = 0$ 时错误概率随 α 的变化.

式 (8.67) 可数值求解，再由 $m = \operatorname{erf}(y)$ 得到 m . 错误概率 $P_{\text{error}} = (1 - m)/2$ 如图 8.3 所示. 在临界值 $\alpha_c = 0.138$ 处，错误概率跃变到 $1/2$ ，表明不连续地转变到自旋玻璃相. 当 $\alpha < \alpha_c$ 时错误概率很低，网络能可靠提取一个存储模式；当 $\alpha > \alpha_c$ 时错误概率为 $1/2$ ，表明网络不再具有显著记忆.

8.3 相图

数值求解式 (8.61)、(8.60) 和 (8.62)，可得 Hopfield 网络的相图 (图 8.4) [3, 6]. 在很高温度下，热噪声破坏提取过程，所以 $m = q = r = 0$. 有趣的是，从逆 Ising 视角看，给定该相中的构型，可以通过逆向工程过程容易地推断模型耦合 [7, 8].

随着温度降低，顺磁相在临界温度-负载线 $T_g(\alpha)$ 处失稳. 对式 (8.60) 作线性稳定性分析可解析得到 $T_g = 1 + \sqrt{\alpha}$ ，其中 α 为记忆负载.

另一方面，随着记忆负载降低，自旋玻璃相在临界线 $T_M(\alpha)$ 处成为亚稳态，提取相则变得局域稳定，因而这是一级相变。在该相中，伪态（若干存储模式的线性组合）也作为亚稳态出现。当 $\alpha < 0.051$ 时，跨过临界温度线 T_c 后提取相成为全局稳定相。不连续转变点可通过分析鞍点方程并令两个竞争相的自由能相等来求取： $T_M \simeq 1 - 1.95\sqrt{\alpha}$ ， $T_c \simeq 1 - 2.6\sqrt{\alpha}$ [6]。




Fig. 8.4 The phase diagram of Hopfield model (adapted from Ref. [3]). Three phases (paramagnetic

图 8.4: Hopfield 模型相图（改绘自文献 [3]）。存在顺磁、自旋玻璃和提取三个相。顺磁相通过连续转变 (T_g 线) 与自旋玻璃相分开；提取相到自旋玻璃相在 T_M 线上发生不连续转变。 T_c 线以下提取相全局稳定；虚线 T_R 以下复制对称解失稳。

在 $T = 0$ 时，每自旋熵

$$S = - \left. \frac{\partial f}{\partial T} \right|_{T \rightarrow 0} = - \frac{\alpha}{2} \left[\ln(1 - C) + \frac{C}{1 - C} \right], \quad C = \beta(1 - q),$$

对所有复制对称解均为负，这在物理上不合理。图 8.4 的虚线以下（自旋玻璃理论中称为 AT 线；见第 9 章），提取态变得不稳定，必须考虑复制对称破缺（RSB）效应；第 9 章将作一般介绍。在物理上，这意味着重叠矩阵不再保持副本指标的置换对称性，须采用更高层次的近似。不过如图 8.4 所示，提取相中的 RSB 效应很弱。当 $\alpha \rightarrow \infty$ 时，Hopfield 模型退化为著名的 SK 模型。

8.4 任意 Hebb 长度的 Hopfield 模型

本节把标准 Hopfield 模型推广到任意 Hebb 长度。其灵感来自训练猴子识别并匹配视觉刺激的实验：训练中保持刺激呈现的时间顺序。实验发现，猴子的颞叶皮层能把刺激的时间关联转化为持续活动模式中的空间相关 [9, 10]。Griniasty 等 [11] 最先对此建

模，在耦合矩阵的构造中取一个 Hebb 长度，即呈现序列中相邻模式也参与 Hebb 学习。修正后的 Hebb 规则使模型出现新的相关吸引子相：某个刺激模式触发的相关吸引子会与刺激周围的相邻模式相关，尽管各模式本身彼此独立。

考虑到 Hebb 学习可发生在更宽的学习时间窗内 [12, 13]，把 Hebb 长度推广到任意值 [14]，定义神经元耦合矩阵

$$J_{ij} = \frac{1}{N} \sum_{\mu=1}^P \left[c \xi_i^\mu \xi_j^\mu + \gamma \sum_{r=1}^d (\xi_i^\mu \xi_j^{\mu+r} + \xi_i^{\mu+r} \xi_j^\mu) \right]. \quad (8.68)$$

其中 c 指定标准 Hebb 强度， γ 指定相距 r 个位置的模式之间的耦合强度， d 是模型的 Hebb 长度。 $d = 1$ 已由先前工作研究 [11, 15]，而 $d = 0$ 恢复标准 Hopfield 模型 [1, 2, 3]。各 ξ_i^μ 独立服从二项分布 $p(\xi_i^\mu = \pm 1) = \frac{1}{2} \delta(\xi_i^\mu + 1) + \frac{1}{2} \delta(\xi_i^\mu - 1)$ 。考虑 P, N 都很大的极限，并定义 $\alpha = P/N$ ，即联想记忆模型的记忆负载。

8.4.1 无序平均自由能的计算

矩阵 $\mathbf{J}$ 可改写为

$$\mathbf{J} = \frac{1}{N} \boldsymbol{\xi}^\top \mathbf{X} \boldsymbol{\xi}, \quad (8.69)$$

其中 $\mathbf{X}$ 是 $P \times P$ 循环矩阵，即 Toeplitz 矩阵的一种特殊形式，其元素为

$$\begin{aligned} X_{\mu\eta} &= c \delta_{\mu\eta} + \gamma \sum_{r=1}^d (\delta_{\mu, (\eta+r) \bmod P} + \delta_{\mu, (\eta-r) \bmod P}) \\ &= (c - \gamma) \delta_{\mu\eta} + \gamma \sum_{r=-d}^d \delta_{\mu, (\eta+r) \bmod P}. \end{aligned} \quad (8.70)$$

$\mathbf{X}$ 的第 m 个特征值为 [16]

$$\begin{aligned} \lambda_m &= \sum_{k=0}^{P-1} X_{1(k+1)} e^{-2\pi i m k / P} \\ &= c + 2\gamma \sum_{r=1}^d \cos\left(\frac{2\pi m r}{P}\right), \quad m = 0, 1, \dots, P-1. \end{aligned} \quad (8.71)$$

模型 Hamiltonian 为

$$H(\mathbf{s}) = -\frac{1}{2} \sum_{i \neq j} J_{ij} s_i s_j, \quad (8.72)$$

配分函数为

$$Z = \text{Tr} \exp \left(\frac{\beta}{2N} \mathbf{s}^\top \boldsymbol{\xi}^\top \mathbf{X} \boldsymbol{\xi} \mathbf{s} \right). \quad (8.73)$$

Tr 表示对所有离散状态 $\mathbf{s}$ 求和. 无序平均自由能 $\langle -T \ln Z \rangle$ 一般计算困难, 但可使用自旋玻璃理论中的复制技巧 [4], 代价是必须对复制矩阵作稍后说明的假设:

$$\langle \ln Z \rangle = \lim_{n \rightarrow 0} \frac{\ln \langle Z^n \rangle}{n}. \quad (8.74)$$

为继续, 先计算配分函数的整数次幂

$$Z^n = \text{Tr} \exp \left[\frac{\beta}{2N} \sum_{a=1}^n (\mathbf{s}^a)^\top \boldsymbol{\xi}^\top \mathbf{X} \boldsymbol{\xi} \mathbf{s}^a \right]. \quad (8.75)$$

考虑存在 S 个凝聚 (前景) 模式和 $P - S$ 个非凝聚 (背景) 模式, 这对当前设定是合理的; 可通过求解平均场动力学或鞍点方程作后验检验. 将 $\mathbf{X}$ 重新组织为分块矩阵

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{FF} & \mathbf{X}_{FB} \\ \mathbf{X}_{BF} & \mathbf{X}_{BB} \end{pmatrix}, \quad (8.76)$$

其中 $\mathbf{X}_{FF} \in \mathbb{R}^{S \times S}$ 、 $\mathbf{X}_{BF}^\top = \mathbf{X}_{FB} \in \mathbb{R}^{S \times (P-S)}$ 、 $\mathbf{X}_{BB} \in \mathbb{R}^{(P-S) \times (P-S)}$. 由此

$$\begin{aligned} Z^n = \text{Tr} \exp & \left[\frac{\beta}{2N} \sum_{\substack{a,i,j \\ \mu,\nu \in B}} s_i^a \xi_i^\mu X_{\mu\nu} \xi_j^\nu s_j^a + \frac{\beta}{N} \sum_{\substack{a,i,j \\ \mu \in B, \nu \in F}} s_i^a \xi_i^\mu X_{\mu\nu} \xi_j^\nu s_j^a \right. \\ & \left. + \frac{\beta}{2N} \sum_{\substack{a,i,j \\ \mu,\nu \in F}} s_i^a \xi_i^\mu X_{\mu\nu} \xi_j^\nu s_j^a \right]. \end{aligned} \quad (8.77)$$

将背景子矩阵对角化为 $X_{\mu\nu}^{BB} = \sum_\sigma \lambda_\sigma \eta_\mu^\sigma \eta_\nu^\sigma$. 作 Hubbard–Stratonovich 变换后,

$$\begin{aligned} Z^n = \text{Tr} \int \prod_{a,\sigma} D x_\sigma^a \exp & \left[\sum_{i,\mu \in B} \frac{\xi_i^\mu}{\sqrt{N}} \left(\sum_{a,\sigma} s_i^a \eta_\mu^\sigma \sqrt{\beta \lambda_\sigma} x_\sigma^a + \sqrt{\frac{\beta}{N}} \sum_{a,j,\nu \in F} s_i^a X_{\mu\nu} \xi_j^\nu s_j^a \right) \right. \\ & \left. + \frac{\beta}{2N} \sum_{\substack{a,i,j \\ \mu,\nu \in F}} s_i^a \xi_i^\mu X_{\mu\nu} \xi_j^\nu s_j^a \right], \end{aligned} \quad (8.78)$$

其中 $Dx = (2\pi)^{-1/2} e^{-x^2/2} dx$. 定义背景与前景两部分

$$\Omega_B = \exp \left[\sum_{i,\mu \in B} \frac{\xi_i^\mu}{\sqrt{N}} \left(\sum_{a,\sigma} s_i^a \eta_\mu^\sigma \sqrt{\beta \lambda_\sigma} x_\sigma^a + \sqrt{\frac{\beta}{N}} \sum_{a,j,\nu \in F} s_i^a X_{\mu\nu} \xi_j^\nu s_j^a \right) \right], \quad (8.79)$$

$$\Omega_F = \exp \left[\frac{\beta}{2N} \sum_{\substack{a,i,j \\ \mu,\nu \in F}} s_i^a \xi_i^\mu X_{\mu\nu} \xi_j^\nu s_j^a \right]. \quad (8.80)$$

对 $\{\xi_i^\mu\}$ 作无序平均:

$$\langle Z^n \rangle = \text{Tr} \left\langle \int \prod_{a,\sigma} D x_\sigma^a \Omega_B \Omega_F \right\rangle. \quad (8.81)$$

先对背景模式分布平均，得到

$$\langle \Omega_B \rangle = \exp \left\{ \frac{1}{2N} \sum_{i, \mu \in B} \left[\sum_a s_i^a \left(\sum_{\sigma} \eta_{\mu}^{\sigma} \sqrt{\beta \lambda_{\sigma}} x_{\sigma}^a + \sqrt{\beta N} \sum_{\nu \in F} X_{\mu\nu} m_{\nu}^a \right) \right]^2 \right\}. \quad (8.82)$$

引入状态重叠 $q_{ab} = N^{-1} \sum_i s_i^a s_i^b$ ($a \neq b$) 和模式重叠 $m_a^{\mu} = N^{-1} \sum_i \xi_i^{\mu} s_i^a$ ，以及相应共轭参数 $\hat{q}_{ab}, \hat{m}_a^{\mu}$ 。插入定义这些序参量的 Dirac delta 函数及其积分表示后，

$$\begin{aligned} \langle \Omega_B \rangle &= \int \frac{\prod_{a \neq b} dq_{ab} d\hat{q}_{ab}}{(2\pi/N)^{n(n-1)}} \frac{\prod_{a, \mu \in F} dm_a^{\mu} d\hat{m}_a^{\mu}}{(2\pi/N)^{nS}} \\ &\times \exp \left[-\frac{N}{2} \sum_{a \neq b} \hat{q}_{ab} q_{ab} + \frac{1}{2} \sum_{a \neq b} \hat{q}_{ab} \sum_i s_i^a s_i^b - N \sum_{a, \mu \in F} m_a^{\mu} \hat{m}_a^{\mu} + \sum_{a, \mu \in F} \hat{m}_a^{\mu} \sum_i \xi_i^{\mu} s_i^a \right] \\ &\times \exp \left\{ \frac{1}{2} \sum_{\mu \in B, a} \left[\sum_{\sigma} \eta_{\mu}^{\sigma} \sqrt{\beta \lambda_{\sigma}} x_{\sigma}^a + \sqrt{\beta N} \sum_{\nu \in F} X_{\mu\nu} m_{\nu}^a \right]^2 \right\} \\ &\times \exp \left\{ \frac{1}{2} \sum_{\mu \in B, a \neq b} q_{ab} A_{\mu}^a A_{\mu}^b \right\}, \quad A_{\mu}^a \equiv \sum_{\sigma} \eta_{\mu}^{\sigma} \sqrt{\beta \lambda_{\sigma}} x_{\sigma}^a + \sqrt{\beta N} \sum_{\nu \in F} X_{\mu\nu} m_{\nu}^a. \end{aligned} \quad (8.83)$$

在复制对称设定 $q_{ab} = q$ 、 $\hat{q}_{ab} = \hat{q}$ ($a \neq b$)、 $m_a^{\mu} = m^{\mu}$ 、 $\hat{m}_a^{\mu} = \hat{m}^{\mu}$ 下，整理平方项：

$$\begin{aligned} \langle \Omega_B \rangle &= \int \frac{dq d\hat{q}}{(2\pi/N)^{n(n-1)}} \frac{d\mathbf{m} d\hat{\mathbf{m}}}{(2\pi/N)^{nS}} \exp \left[-\frac{N}{2} n(n-1) \hat{q} q + \frac{\hat{q}}{2} \sum_{a \neq b, i} s_i^a s_i^b - N n \sum_{\mu \in F} m^{\mu} \hat{m}^{\mu} + \sum_{a, \mu \in F} \hat{m}^{\mu} \sum_i \xi_i^{\mu} s_i^a \right] \\ &\times \exp \left[\frac{1-q}{2} \sum_{\mu \in B, a} (A_{\mu}^a)^2 + \frac{q}{2} \sum_{\mu \in B} \left(\sum_a A_{\mu}^a \right)^2 \right]. \end{aligned} \quad (8.84)$$

再次应用 Hubbard-Stratonovich 变换：

$$\begin{aligned} \langle \Omega_B \rangle &= \int \frac{dq d\hat{q}}{(2\pi/N)^{n(n-1)}} \frac{d\mathbf{m} d\hat{\mathbf{m}}}{(2\pi/N)^{nS}} \prod_{\mu, a} Dy_{\mu}^a \prod_{\mu} Dz_{\mu} e^{\mathcal{A}} \\ &\times \exp \left[\sqrt{1-q} \sum_{\mu \in B, a} A_{\mu}^a y_{\mu}^a + \sqrt{q} \sum_{\mu \in B, a} A_{\mu}^a z_{\mu} \right], \end{aligned} \quad (8.85)$$

其中 $\mathcal{A}$ 表示式 (8.84) 第一指数中的序参量约束项。收集 x_{σ}^a 的项，

$$\begin{aligned} \langle \Omega_B \rangle &= \int \cdots \exp \left[\sum_{a, \sigma} x_{\sigma}^a \sqrt{\beta \lambda_{\sigma}} \sum_{\mu \in B} \eta_{\mu}^{\sigma} (\sqrt{1-q} y_{\mu}^a + \sqrt{q} z_{\mu}) \right] \\ &\times \exp \left[\beta \sqrt{N} \sum_{a, \mu \in B, \nu \in F} X_{\mu\nu} m_{\nu}^a (\sqrt{1-q} y_{\mu}^a + \sqrt{q} z_{\mu}) \right] e^{\mathcal{A}}. \end{aligned} \quad (8.86)$$

按重叠定义，前景部分为

$$\Omega_F = \exp \left[\frac{\beta n N}{2} \sum_{\mu, \nu \in F} m^{\mu} X_{\mu\nu} m^{\nu} \right]. \quad (8.87)$$

汇总上述结果：

$$\begin{aligned}
\langle Z^n \rangle = & \text{Tr} \int \prod_{a,\sigma} Dx_\sigma^a \frac{dq d\hat{q}}{(2\pi/N)^{n(n-1)}} \frac{d\mathbf{m} d\widehat{\mathbf{m}}}{(2\pi/N)^{nS}} \prod_{\mu,a} Dy_\mu^a \prod_{\mu} Dz_\mu \\
& \times e^{\mathcal{A}} \exp \left[\sum_{a,\sigma} x_\sigma^a \sqrt{\beta \lambda_\sigma} \sum_{\mu \in B} \eta_\mu^\sigma (\sqrt{1-q} y_\mu^a + \sqrt{q} z_\mu) \right] \\
& \times \exp \left[\beta \sqrt{N} \sum_{a,\mu \in B, \nu \in F} X_{\mu\nu} m^\nu (\sqrt{1-q} y_\mu^a + \sqrt{q} z_\mu) \right] \Omega_F. \quad (8.88)
\end{aligned}$$

定义对 $\{s_i^a\}$ 的求和项

$$\begin{aligned}
\langle \Omega_S \rangle = & \text{Tr} \exp \left[\frac{\hat{q}}{2} \sum_{a \neq b, i} s_i^a s_i^b + \sum_{a, \mu \in F} \widehat{m}^\mu \sum_i \xi_i^\mu s_i^a \right] \\
= & \exp \left(-\frac{nN}{2} \hat{q} \right) \left\{ \text{Tr} \exp \left[\frac{\hat{q}}{2} \left(\sum_a s^a \right)^2 + \sum_{a, \mu \in F} \widehat{m}^\mu \xi^\mu s^a \right] \right\}^N. \quad (8.89)
\end{aligned}$$

作 Hubbard-Stratonovich 变换：

$$\langle \Omega_S \rangle = \exp \left(-\frac{nN}{2} \hat{q} \right) \exp \left\{ N \ln \int Dz \left[2 \cosh \left(\sqrt{\hat{q}} z + \sum_{\mu \in F} \widehat{m}^\mu \xi^\mu \right) \right]^n \right\}. \quad (8.90)$$

在 $n \rightarrow 0$ 极限，

$$\langle \Omega_S \rangle = \exp \left(-\frac{nN}{2} \hat{q} \right) \exp \left\{ nN \int Dz \ln \left[2 \cosh \left(\sqrt{\hat{q}} z + \sum_{\mu \in F} \widehat{m}^\mu \xi^\mu \right) \right] \right\}. \quad (8.91)$$

于是

$$\begin{aligned}
\langle Z^n \rangle = & \int \cdots \exp \left[-\frac{N}{2} n(n-1) \hat{q} q - \frac{nN}{2} \hat{q} - N n \mathbf{m}^\top \widehat{\mathbf{m}} + \frac{\beta n N}{2} \mathbf{m}^\top \mathbf{X}_{FF} \mathbf{m} \right] \\
& \times \exp \left[nN \int Dz \ln 2 \cosh \left(\sqrt{\hat{q}} z + \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) \right] \times (\text{式 (8.88) 中的 Gaussian 因子}). \quad (8.92)
\end{aligned}$$

令 $\mathbf{y}^a = [y_\mu^a; \mu \in B]^\top$ 、 $\mathbf{z} = [z_\mu; \mu \in B]^\top$ 、 $\mathbf{m} = [m^\mu; \mu \in F]^\top$ 、 $\widehat{\mathbf{m}} = [\widehat{m}^\mu; \mu \in F]^\top$ 。积分掉 $\{x_\sigma^a\}$ ：

$$\begin{aligned}
& \int \prod_{a,\sigma} Dx_\sigma^a \exp \left[\sum_{a,\sigma} x_\sigma^a \sqrt{\beta \lambda_\sigma} \sum_{\mu \in B} \eta_\mu^\sigma (\sqrt{1-q} y_\mu^a + \sqrt{q} z_\mu) \right] \\
& = \exp \left[\frac{\beta}{2} (1-q) \sum_a (\mathbf{y}^a)^\top \mathbf{X}_{BB} \mathbf{y}^a + \beta \sqrt{(1-q)q} \sum_a \mathbf{z}^\top \mathbf{X}_{BB} \mathbf{y}^a + \frac{n\beta q}{2} \mathbf{z}^\top \mathbf{X}_{BB} \mathbf{z} \right]. \quad (8.93)
\end{aligned}$$

收集并积分掉 $\{y_\mu^a\}$, 得到

$$\begin{aligned}
& [\det(\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})]^{-n/2} \\
& \times \exp \left[\frac{nN\beta^2(1-q)}{2} \mathbf{m}^\top \mathbf{X}_{FB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BF} \mathbf{m} \right] \\
& \times \exp \left[\frac{n\beta^2(1-q)q}{2} \mathbf{z}^\top \mathbf{X}_{BB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB} \mathbf{z} \right] \\
& \times \exp \left[n\beta^2 \sqrt{Nq(1-q)} \mathbf{m}^\top \mathbf{X}_{FB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB} \mathbf{z} \right]. \quad (8.94)
\end{aligned}$$

再收集 $\mathbf{z}$ 的项, 并在 $n \rightarrow 0$ 极限积分:

$$\begin{aligned}
& \int D\mathbf{z} \exp \left\{ -\frac{1}{2} \mathbf{z}^\top [\mathbf{I} - n\beta q \mathbf{X}_{BB} - n\beta^2(1-q)q \mathbf{X}_{BB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB}] \mathbf{z} + \dots \right\} \\
& = \exp \left\{ -\frac{1}{2} \ln \det [\mathbf{I} - n\beta q \mathbf{X}_{BB} - n\beta^2(1-q)q \mathbf{X}_{BB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB}] \right\}, \quad (8.95)
\end{aligned}$$

其中忽略 $O(n^2)$ 项.

综上,

$$\begin{aligned}
\langle Z^n \rangle &= \int \frac{dq d\hat{q}}{(2\pi/N)^{n(n-1)}} \frac{d\mathbf{m} d\widehat{\mathbf{m}}}{(2\pi/N)^{nS}} \exp \left\{ nN \int D\mathbf{z} \ln \left[2 \cosh(\sqrt{\hat{q}} \mathbf{z} + \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F) \right] \right\} \\
& \times \exp \left[-\frac{N}{2} n(n-1) \hat{q} q - \frac{nN}{2} \hat{q} - N n \mathbf{m}^\top \widehat{\mathbf{m}} + \frac{\beta n N}{2} \mathbf{m}^\top \mathbf{X}_{FF} \mathbf{m} \right] \\
& \times [\det(\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})]^{-n/2} \\
& \times \exp \left[\frac{nN\beta^2(1-q)}{2} \mathbf{m}^\top \mathbf{X}_{FB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BF} \mathbf{m} \right] \\
& \times \exp \left\{ -\frac{1}{2} \ln \det [\mathbf{I} - n\beta q \mathbf{X}_{BB} - n\beta^2(1-q)q \mathbf{X}_{BB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB}] \right\}. \quad (8.96)
\end{aligned}$$

应用 Laplace 方法, 平均自由能为

$$\begin{aligned}
-\beta f \equiv \frac{1}{N} \langle \ln Z \rangle &= \int D\mathbf{z} \ln \left[2 \cosh(\sqrt{\hat{q}} \mathbf{z} + \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F) \right] + \frac{1}{2} \hat{q} q - \frac{1}{2} \hat{q} - \mathbf{m}^\top \widehat{\mathbf{m}} + \frac{\beta}{2} \mathbf{m}^\top \mathbf{X}_{FF} \mathbf{m} \\
& - \frac{1}{2N} \ln \det [\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}] + \frac{\beta^2(1-q)}{2} \mathbf{m}^\top \mathbf{X}_{FB} [\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}]^{-1} \mathbf{X}_{BF} \mathbf{m} \\
& - \lim_{n \rightarrow 0} \frac{1}{2nN} \ln \det [\mathbf{I} - n\beta q \mathbf{X}_{BB} - n\beta^2(1-q)q \mathbf{X}_{BB} (\mathbf{I} - \beta(1-q)\mathbf{X}_{BB})^{-1} \mathbf{X}_{BB}]. \quad (8.97)
\end{aligned}$$

最后两类行列式项可化简为

$$-\frac{1}{2N} \ln \det [\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}] = -\frac{1}{2N} \sum_{\sigma} \ln [1 - \beta(1-q)\lambda_{\sigma}], \quad (8.98)$$

$$-\lim_{n \rightarrow 0} \frac{1}{2nN} \ln \det [\dots] = \frac{1}{2N} \sum_{\sigma} \frac{\beta q \lambda_{\sigma}}{1 - \beta(1-q)\lambda_{\sigma}}. \quad (8.99)$$

因此

$$\begin{aligned} \frac{1}{N} \langle \ln Z \rangle = & \int Dz \ln \left[2 \cosh(\sqrt{\hat{q}} z + \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F) \right] + \frac{1}{2} \hat{q}(q-1) - \mathbf{m}^\top \widehat{\mathbf{m}} + \frac{\beta}{2} \mathbf{m}^\top \mathbf{X}_{FF} \mathbf{m} \\ & - \frac{1}{2N} \sum_{\sigma} \ln[1 - \beta(1-q)\lambda_{\sigma}] + \frac{\beta^2(1-q)}{2} \mathbf{m}^\top \mathbf{X}_{FB} [\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}]^{-1} \mathbf{X}_{BF} \mathbf{m} \\ & + \frac{1}{2N} \sum_{\sigma} \frac{\beta q \lambda_{\sigma}}{1 - \beta(1-q)\lambda_{\sigma}}. \end{aligned} \quad (8.100)$$

重标度 $\hat{q} \rightarrow \beta^2 \hat{q}$ 、 $\widehat{\mathbf{m}} \rightarrow \beta \widehat{\mathbf{m}}$ ，并定义

$$\mathbf{K} = \mathbf{X}_{FF} + \beta(1-q)\mathbf{X}_{FB}[\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}]^{-1}\mathbf{X}_{BF}. \quad (8.101)$$

自由能关于 $\mathbf{m}$ 的稳定条件给出 $\widehat{\mathbf{m}} = \mathbf{K}\mathbf{m}$ 。于是自由能可整理为

$$\begin{aligned} -\beta f = & \frac{\beta^2 \hat{q}}{2}(q-1) - \frac{\beta}{2} \mathbf{m}^\top \mathbf{K} \mathbf{m} - \frac{\alpha}{2} \int_0^1 du \ln[1 - \beta(1-q)\Lambda(u)] \\ & + \frac{\alpha\beta q}{2} \int_0^1 du \frac{\Lambda(u)}{1 - \beta(1-q)\Lambda(u)} + \int Dz \ln \left[2 \cosh \left(\beta \sqrt{\hat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) \right], \end{aligned} \quad (8.102)$$

其中 $\Lambda(u) = c + 2\gamma \sum_{r=1}^d \cos(2\pi r u)$ 。当 $P \rightarrow \infty$ 时，可以证明 $\mathbf{X}_{BB}$ 与 $\mathbf{X}$ 渐近等价 [16]，故可利用循环矩阵 $\mathbf{X}$ 的特征值把对 σ 的求和替换为积分。

8.4.2 鞍点方程的推导

序参量应取使自由能函数优化的值，从而得到鞍点方程（SDE）。关于 q 的鞍点条件依次给出

$$q - 1 + \frac{1}{\beta \sqrt{\hat{q}}} \int Dz z \tanh \left(\beta \sqrt{\hat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) = 0, \quad (8.103)$$

$$q - 1 + \int Dz \left[1 - \tanh^2 \left(\beta \sqrt{\hat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) \right] = 0, \quad (8.104)$$

$$q = \int Dz \tanh^2 \left(\beta \sqrt{\hat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right). \quad (8.105)$$

关于 $\widehat{\mathbf{m}}$ 的鞍点方程为

$$\mathbf{m} = \left\langle \boldsymbol{\xi}_F \int Dz \tanh \left(\beta \sqrt{\hat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) \right\rangle_{\boldsymbol{\xi}_F}. \quad (8.106)$$

关于 $\mathbf{m}$ 的方程为

$$\widehat{\mathbf{m}} = \mathbf{X}_{FF} \mathbf{m} + \beta(1-q)\mathbf{X}_{FB}[\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}]^{-1}\mathbf{X}_{BF} \mathbf{m} \equiv \mathbf{K} \mathbf{m}. \quad (8.107)$$

关于 $\hat{q}$ 的方程为

$$\begin{aligned} \hat{q} = & \frac{1}{N} \sum_{\sigma} \frac{q \lambda_{\sigma}^2}{[1 - \beta(1-q)\lambda_{\sigma}]^2} + \mathbf{m}^\top \mathbf{X}_{FB} [\mathbf{I} - \beta(1-q)\mathbf{X}_{BB}]^{-2} \mathbf{X}_{BF} \mathbf{m} \\ = & \alpha q \int_0^1 du \frac{\Lambda^2(u)}{[1 - \beta(1-q)\Lambda(u)]^2} - \beta^{-1} \mathbf{m}^\top \frac{\partial \mathbf{K}}{\partial q} \mathbf{m}. \end{aligned} \quad (8.108)$$

最终，鞍点方程汇总为

$$\widehat{\mathbf{m}} = \mathbf{K} \mathbf{m}, \quad (8.109a)$$

$$q = \int Dz \tanh^2 \left(\beta \sqrt{\widehat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right), \quad (8.109b)$$

$$\widehat{q} = \alpha q \int_0^1 du \frac{\Lambda^2(u)}{[1 - \beta(1-q)\Lambda(u)]^2} - \beta^{-1} \mathbf{m}^\top \frac{\partial \mathbf{K}}{\partial q} \mathbf{m}, \quad (8.109c)$$

$$\mathbf{m} = \left\langle \boldsymbol{\xi}_F \int Dz \tanh \left(\beta \sqrt{\widehat{q}} z + \beta \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F \right) \right\rangle_{\boldsymbol{\xi}_F}. \quad (8.109d)$$

下面确定顺磁相与自旋玻璃相之间的临界温度. 自旋玻璃相中 $q \neq 0$ 、 $\mathbf{m} = 0$. 把 $q, \widehat{q}$ 的方程对小量展开:

$$q \simeq \beta^2 \widehat{q} \simeq \beta^2 \alpha q \int_0^1 du \frac{\Lambda^2(u)}{[1 - \beta \Lambda(u)]^2} + O(q^2). \quad (8.110)$$

因而 T_g 由

$$1 = \alpha \int_0^1 du \frac{\Lambda^2(u)}{[T_g - \Lambda(u)]^2} \quad (8.111)$$

确定. 对标准 Hopfield 模型, 该式可解析求解, 得到 $T_g = 1 + \sqrt{\alpha}$.

8.4.3 求解鞍点方程的计算变换

数值求解 SDE 的困难在于 $\mathbf{K}$ 涉及 $\mathbf{X}$ 的分块结构. 为消除对 N, P 的依赖 (只关心大 N, P 极限), 定义 $C = \beta(1-q)$.

若 $C = 0$, 则 $\mathbf{K} = \mathbf{X}_{FF}$ 、 $\partial \mathbf{K} / \partial C = \mathbf{X}_{FB} \mathbf{X}_{BF}$. 令

$$\mathbf{X} \mathbf{X}^\top = \begin{pmatrix} \mathbf{H} & \cdots \\ \cdots & \cdots \end{pmatrix}, \quad (8.112)$$

其中 $\mathbf{H}$ 为 $S \times S$ 对称矩阵, 则

$$\mathbf{H} = \mathbf{X}_{FF} \mathbf{X}_{FF}^\top + \mathbf{X}_{FB} \mathbf{X}_{BF} = \mathbf{X}_{FF} \mathbf{X}_{FF}^\top + \left. \frac{\partial \mathbf{K}}{\partial C} \right|_{C=0}. \quad (8.113)$$

$\mathbf{H}$ 可写为

$$\mathbf{H} = \begin{pmatrix} h_0 & h_1 & \cdots & h_{S-1} \\ h_1 & h_0 & \cdots & h_{S-2} \\ \vdots & \vdots & \ddots & \vdots \\ h_{S-1} & h_{S-2} & \cdots & h_0 \end{pmatrix}, \quad (8.114)$$

其中

$$\begin{aligned} h_l &= \frac{1}{P} \sum_{m=0}^{P-1} \left[c + 2\gamma \sum_{r=1}^d \cos \left(\frac{2\pi r m}{P} \right) \right]^2 e^{2\pi i m l / P} \\ &= \int_0^1 dx \left[c + 2\gamma \sum_{r=1}^d \cos(2\pi r x) \right]^2 \cos(2\pi l x). \end{aligned} \quad (8.115)$$

于是

$$\left. \frac{\partial \mathbf{K}}{\partial C} \right|_{C=0} = \mathbf{H} - (\mathbf{K}|_{C=0})^2. \quad (8.116)$$

若 $C \neq 0$, 则 $\mathbf{K} = \mathbf{X}_{FF} - \mathbf{X}_{FB}(\mathbf{X}_{BB} - C^{-1}\mathbf{I})^{-1}\mathbf{X}_{BF}$. 在大 P 极限数值计算 $\mathbf{K}$ 时, 注意

$$(\mathbf{X} - C^{-1}\mathbf{I})^{-1} = \begin{pmatrix} \mathbf{F}_1^{-1} & \cdots \\ \cdots & \cdots \end{pmatrix}, \quad (8.117)$$

其中 $\mathbf{F}_1^{-1} \in \mathbb{R}^{S \times S}$. 由于 $\mathbf{X} - C^{-1}\mathbf{I}$ 是循环矩阵, 其逆矩阵为 $\text{Circ}(w_0, \dots, w_{P-1})$, 其中

$$w_k = \int_0^1 dx \frac{\cos(2\pi kx)}{c - C^{-1} + 2\gamma \sum_{r=1}^d \cos(2\pi rx)}, \quad k = 0, \dots, P-1. \quad (8.118)$$

因此

$$\mathbf{F}_1^{-1} = \begin{pmatrix} w_0 & w_1 & \cdots & w_{S-1} \\ w_1 & w_0 & \cdots & w_{S-2} \\ \vdots & \vdots & \ddots & \vdots \\ w_{S-1} & w_{S-2} & \cdots & w_0 \end{pmatrix}. \quad (8.119)$$

利用分块矩阵求逆公式可证明

$$\mathbf{K} = \mathbf{F}_1 + C^{-1}\mathbf{I}. \quad (8.120)$$

数值计算时, 先算 $k = 0, \dots, S-1$ 的 w_k 得到 $\mathbf{F}_1^{-1}$, 再求逆得到 $\mathbf{F}_1$, 最后加上 $C^{-1}\mathbf{I}$. 导数 $\partial \mathbf{K} / \partial C = -\beta^{-1} \partial \mathbf{K} / \partial q$ 为

$$\frac{\partial \mathbf{K}}{\partial C} = \frac{\partial \mathbf{F}_1}{\partial C} - C^{-2}\mathbf{I} = -\mathbf{F}_1 \frac{\partial \mathbf{F}_1^{-1}}{\partial C} \mathbf{F}_1 - C^{-2}\mathbf{I}, \quad (8.121)$$

而 $\partial \mathbf{F}_1^{-1} / \partial C$ 的矩阵元由

$$\frac{\partial w_k}{\partial C} = - \int_0^1 dx \frac{C^{-2} \cos(2\pi kx)}{[c - C^{-1} + 2\gamma \sum_{r=1}^d \cos(2\pi rx)]^2}, \quad k = 0, \dots, S-1 \quad (8.122)$$

计算.

8.4.4 零温极限

当 $T \rightarrow 0$ ($\beta \rightarrow \infty$) 时,

$$\int Dz \tanh[\beta(\sqrt{\hat{q}}z + x)] = \text{erf}\left(\frac{x}{\sqrt{2\hat{q}}}\right) + O(T), \quad (8.123)$$

并且

$$\int \frac{dz}{\sqrt{2\pi}} e^{-z^2/2} \{1 - \tanh^2[\beta(az + b)]\} = \sqrt{\frac{2}{\pi}} \frac{1}{a\beta} e^{-b^2/(2a^2)}. \quad (8.124)$$

于是

$$\mathbf{m} = \left\langle \boldsymbol{\xi}_F \operatorname{erf} \left(\frac{\boldsymbol{\xi}_F^\top \mathbf{K} \mathbf{m}}{\sqrt{2\hat{q}}} \right) \right\rangle_{\boldsymbol{\xi}_F}. \quad (8.125)$$

零温极限还给出

$$\begin{aligned} \beta(1-q) &= \beta \int Dz \left\{ 1 - \tanh^2 \left[\beta \sqrt{\hat{q}} z + \beta \boldsymbol{\xi}_F^\top \mathbf{K} \mathbf{m} \right] \right\} \\ &= \sqrt{\frac{2}{\pi \hat{q}}} \left\langle \exp \left[-\frac{(\boldsymbol{\xi}_F^\top \mathbf{K} \mathbf{m})^2}{2\hat{q}} \right] \right\rangle_{\boldsymbol{\xi}_F} \equiv C. \end{aligned} \quad (8.126)$$

共轭序参量为

$$\hat{q} = \alpha \int_0^1 du \frac{\Lambda^2(u)}{[1 - C\Lambda(u)]^2} + \mathbf{m}^\top \frac{\partial \mathbf{K}}{\partial C} \mathbf{m}, \quad (8.127)$$

这里零温极限下 $q \rightarrow 1$. 零温自由能为

$$\begin{aligned} -f &= \frac{\alpha}{2} \int_0^1 du \frac{\Lambda(u)}{1 - C\Lambda(u)} - \frac{C\hat{q}}{2} - \frac{1}{2} \mathbf{m}^\top \mathbf{K} \mathbf{m} \\ &+ \left\langle \sqrt{\frac{2a}{\pi}} e^{-b^2/(2a)} + b \operatorname{erf} \left(\frac{b}{\sqrt{2a}} \right) \right\rangle_{\boldsymbol{\xi}_F}, \quad a = \hat{q}, \quad b = \widehat{\mathbf{m}}^\top \boldsymbol{\xi}_F. \end{aligned} \quad (8.128)$$

自旋玻璃解. SDE 的自旋玻璃解满足 $m^\mu = 0$ ($\mu = 1, \dots, S$), 因而

$$C = \sqrt{\frac{2}{\pi \hat{q}}}, \quad (8.129)$$

$$\hat{q} = \alpha \int_0^1 du \frac{\Lambda^2(u)}{[1 - C\Lambda(u)]^2}. \quad (8.130)$$

考虑最简单的 $\gamma = 0, c = 1$, 立即有

$$\hat{q} = \frac{\alpha}{(1 - C)^2}. \quad (8.131)$$

因此 $C = (1 + \sqrt{\pi\alpha/2})^{-1}$, 恢复标准 Hopfield 模型的结果.

提取解. 铁磁相只有一个非零重叠 $m^\mu = m\delta_{\mu,1} \sim O(1)$, 称为提取态, 由下列方程刻画:

$$m = \left\langle \xi^1 \operatorname{erf} \left[\frac{m \boldsymbol{\xi}_F^\top \mathbf{K}_{\cdot 1}}{\sqrt{2\hat{q}}} \right] \right\rangle_{\boldsymbol{\xi}_F}, \quad (8.132a)$$

$$C = \sqrt{\frac{2}{\pi \hat{q}}} \left\langle \exp \left[-\frac{(m \boldsymbol{\xi}_F^\top \mathbf{K}_{\cdot 1})^2}{2\hat{q}} \right] \right\rangle_{\boldsymbol{\xi}_F}, \quad (8.132b)$$

$$\hat{q} = \alpha \int_0^1 du \frac{\Lambda^2(u)}{[1 - C\Lambda(u)]^2} + \left(\frac{\partial \mathbf{K}}{\partial C} \right)_{11} m^2. \quad (8.132c)$$

在最简单的 $\gamma = 0, c = 1$ 情形, $\mathbf{K} = \mathbf{I}$, 上述方程约化为

$$m = \operatorname{erf} \left(\frac{m}{\sqrt{2\hat{q}}} \right), \quad (8.133a)$$

$$C = \sqrt{\frac{2}{\pi\hat{q}}} e^{-m^2/(2\hat{q})}, \quad (8.133b)$$

$$\hat{q} = \frac{\alpha}{(1-C)^2}. \quad (8.133c)$$

该结果给出记忆容量 $\alpha_c \simeq 0.138$; 超过它便只有 $m = 0$, 与标准 Hopfield 网络的容量严格相同 [3]. 一般情形下必须数值求解完整方程.




Fig. 8.5 Phase diagram of the associative memory model in the (α, γ) plane given $c = 1$. **a** The phase boundary shown by the lines delimits the retrieval (R) phase from the region where the correlated-attractor (CA) and spin glass (SG) phases compete with each other (above the boundary). The boundary is the condition on which the retrieval phase loses its metastability from below. All shown transitions are of the discontinuous type. When $\alpha = 0$, the transition point is given by $\gamma_c = 0.5$ for $d = 1$, while $\gamma_c = 0.25$ for $d = 2$. The inset shows the boundary line above which the

图 8.5: 取 $c = 1$ 时, 联想记忆模型在 (α, γ) 平面上的相图. (a) 边界线把提取 (R) 相与相关吸引子 (CA) 相和自旋玻璃 (SG) 相竞争的区域分开; 边界是提取相从下方失去亚稳性的条件, 所示转变均不连续. $\alpha = 0$ 时, $d = 1$ 的转变点为 $\gamma_c = 0.5$, $d = 2$ 为 $\gamma_c = 0.25$. 插图给出自旋玻璃相占优的边界; $d = 1$ 时有一个很窄的阴影区, 其中相关吸引子相占优. (b) 统计力学理论所得重叠轮廓, 均由 $\alpha = 0$ 、 $d = 2$ (或 $d = 1$) 时的鞍点方程求得. 除负 γ 取 $S = 15$ 外, 理论结果取 $S = 11$; 结果对 S 的选择不敏感.

最后考察相图. 图 8.5(a) 显示三个相. 提取相中只有一个重叠分量为一阶量, 即 $m^\mu = m\delta_{\mu\nu}$, 其中 ν 表示刺激模式. 固定 α 增大 γ , 最终使提取相失去亚稳性, 随后相关吸引子相成为亚稳态; 分隔两相的线因而是一级转变. 相关吸引子相的特征是刺激诱发的吸引子与存储序列中有限数目的模式高度相关: 相应重叠随序列中的模式同刺激模式间的距离衰减. 复制理论鞍点方程的数值解 [见零温极限, 图 8.5(b)] 再现了重叠平均场动力学的关键特征, 对应理论中的 $\alpha = 0$.

理论预言 Hebb 长度 d 能扩展相关吸引子的相关跨度, 并显著重塑相图. $\alpha = 0$ 时, 支配提取相的阈值在 $d = 1$ 时为 $\gamma_c = 0.5$, 在 $d = 2$ 时为 $\gamma_c = 0.25$. 有限 α 下, $d = 2$

的提取相在比 $d = 1$ 更小的 γ 处失去亚稳性. 此后 $m^\mu = 0$ 的自旋玻璃相出现并与相关吸引子相竞争, 直至自旋玻璃相成为自由能的全局极小值. 值得注意的是, 对 $d = 1$, $\gamma > 0.5$ 存在相关吸引子相占优的狭窄区; 随着 γ 增加该区域逐渐收缩. 若允许非零温下的噪声神经动力学, 自旋玻璃相将在连续转变处被顺磁相取代 [17], 该转变线也强烈依赖 Hebb 长度.

当 α 接近自旋玻璃线时, 相关吸引子相的重叠峰值降低, 这符合较大记忆负载下记忆干扰显著增强的预期. 在 $\alpha = 0$ 时, $d = 2$ 的相关轮廓比 $d = 1$ 更能抵抗 γ 增大. 继续增大 γ 可能使相关不再局域化, 网络失去对刺激的联想能力.

特别地, 理论分析还再现了平均场动力学中观察到的去学习效应 [14], 并预言振荡相的临界强度: $d = 2$ 时 $\gamma_c = -0.25$, $d = 1$ 时 $\gamma_c = -0.5$. 当 $\gamma < \gamma_c$ 时, 非同时反 Hebb 项的去学习效应更明显, 会偏好某些特定模式而非其符号反转模式. 换言之, Hamiltonian 的自旋反转对称性被打破, 负 γ 选择特定模式, 表明能量景观被重塑、信息存储进一步优化 [18, 19, 20]. 这一现象由此建立了 Hebb 长度、反 Hebb 效应和去学习记忆功能之间的联系.

参考文献

- [1] S. I. Amari, Biol. Cybern. 26, 175 (1977).
- [2] J. J. Hopfield, Proc. Natl. Acad. Sci. USA 79, 2554 (1982).
- [3] D. J. Amit, H. Gutfreund, and H. Sompolinsky, Phys. Rev. Lett. 55(14), 1530 (1985).
- [4] M. Mézard, G. Parisi, and M. A. Virasoro, *Spin Glass Theory and Beyond* (World Scientific, Singapore, 1987).
- [5] D. J. Amit, H. Gutfreund, and H. Sompolinsky, Phys. Rev. A 32, 1007 (1985).
- [6] D. J. Amit, H. Gutfreund, and H. Sompolinsky, Ann. Phys. 173(1), 30 (1987).
- [7] H. Huang, Phys. Rev. E 81, 036104 (2010).
- [8] H. Huang, Phys. Rev. E 82, 056111 (2010).
- [9] Y. Miyashita, Nature 335, 817 (1988).
- [10] Y. Miyashita and H. Chang, Nature 331, 68 (1988).
- [11] M. Griniasty, M. V. Tsodyks, and D. J. Amit, Neural Comput. 5(1), 1 (1993).
- [12] K. C. Bittner, A. D. Milstein, C. Grienberger, S. Romani, and J. C. Magee, Science 357(6355), 1033 (2017).
- [13] W. Gerstner, M. Lehmann, V. Liakoni, D. Corneil, and J. Brea, Front. Neural Circuits 12, 53 (2018).

- [14] Z. Jiang, J. Zhou, T. Hou, K. Y. M. Wong, and H. Huang, arXiv:2103.14317 (2021).
- [15] L. F. Cugliandolo and M. V. Tsodyks, J. Phys. A 27(3), 741 (1994).
- [16] R. M. Gray, Found. Trends Commun. Inf. Theory 2(3), 155 (2006).
- [17] J. Zhou, Z. Jiang, T. Hou, Z. Chen, K. Y. M. Wong, and H. Huang, arXiv:2103.14324 (2021).
- [18] A. Fachechi, E. Agliari, and A. Barra, Neural Netw. 112, 24 (2019).
- [19] V. S. Dotsenko, N. D. Yarunin, and E. A. Dorotheyev, J. Phys. A 24(10), 2419 (1991).
- [20] K. Nokura, J. Phys. A 31(37), 7447 (1998).

复制对称与复制对称破缺

本章介绍复制对称和复制对称破缺 (replica symmetry breaking, RSB) 背后的物理；它们对理解神经网络的自旋玻璃模型十分重要。复制对称设定是计算自由能淬火平均的第一层近似。当该设定失稳或给出不合物理的结果时，必须打破副本指标的置换对称性，从而进入更高层次的复制对称破缺近似。

9.1 广义自由能与态复杂度

前几章分析无序系统（例如 Hopfield 模型）时，通常把复制对称作为统计力学分析的第一步。其物理图像是一个巨大的纯态支配待研究模型的相空间。换言之，自旋-自旋关联随距离衰减，满足簇分解（成簇）性质 [1]；例如在含 N 个粒子的平均场系统中，关联强度为 $O(N^{-1/2})$ [1]。这通常发生在相对高温，如图 9.1 虚线所示。

温度降低时，巨态分裂为许多彼此远离的纯态；相应自由能曲线具有许多由高势垒分隔的局域极小值。每个极小值对应 TAP 方程或 BP 方程的一个不动点 [2]，并贡献统计权重 $e^{-\beta F_\alpha} / \sum_\alpha e^{-\beta F_\alpha}$ ，其中 F_α 是编号 α 的态的自由能， β 为逆温。




图 9.1: 相空间成簇组织出现的示意图。图中只画出三个构型簇，每个簇内均满足纯态的成簇性质；右图为相应自由能景观。

为描述 Gibbs 测度的分解 [3]，需引入刻画自由能水平涨落的额外参数 y ：

$$e^{-y\Phi} = \sum_{\alpha} e^{-yF_{\alpha}} = \int df e^{N[-yf + \Sigma(f)]}. \quad (9.1)$$

$\Sigma(f)$ 编码指数多个态的复杂度，是标准统计力学熵的推广； Φ 是复制或广义自由能，把自由能景观中许多局域极小值之间的涨落纳入考虑。这称为一步复制对称破缺 (1RSB)

情形，本章末节将从数学上详述. 等价地， $e^{-y\Phi} = \sum_{\alpha} Z_{\alpha}^m$ ，即第 α 个态的原配分函数以幂 m 加权； m 称为 Parisi RSB 参数或 Parisi 参数 [4]. 因而可把 y 解释为 βm .

热力学极限下，式 (9.1) 的积分可用 Laplace 近似：

$$-y\phi = \max_f \{\Sigma(f) - yf\}, \quad (9.2)$$

$$y = \frac{\partial \Sigma(f)}{\partial f}, \quad (9.3)$$

其中 ϕ 是每自旋复制自由能密度. Legendre 变换给出

$$f = \frac{\partial(y\phi)}{\partial y}, \quad (9.4)$$

$$\Sigma = y(f - \phi) = y^2 \frac{\partial \phi}{\partial y}. \quad (9.5)$$

ϕ 可由 1RSB 层次的腔方法估计. 在原因子图中加入一个变量节点（例如自旋），并假定腔操作前后的纯态（至少最低自由能态）一一对应，则

$$e^{-y\phi_i^{\text{new}}} = \sum_{\alpha} e^{-yF_{\alpha} - y\Delta F_i^{\alpha}} = e^{-y\phi^{\text{old}}} \langle e^{-y\Delta F_i} \rangle, \quad (9.6)$$

其中态权重 $\omega(\alpha) = e^{-yF_{\alpha}} / \sum_{\alpha} e^{-yF_{\alpha}}$ ，尖括号表示对所有平衡态平均. 类似地，加入函数节点的贡献为

$$e^{-y\phi_a^{\text{new}}} = e^{-y\phi^{\text{old}}} \langle e^{-y\Delta F_a} \rangle. \quad (9.7)$$

两种腔操作引起的复制自由能移动为

$$-y\Delta\phi_i = \ln \langle e^{-y\Delta F_i} \rangle, \quad (9.8)$$

$$-y\Delta\phi_a = \ln \langle e^{-y\Delta F_a} \rangle. \quad (9.9)$$

$\Delta F_i, \Delta F_a$ 可在各纯态内部估计，因而与 RS 理论形式相同. 在 1RSB 层次应用 Bethe 近似：

$$\phi = \sum_i \Delta\phi_i - \sum_a (|\partial a| - 1) \Delta\phi_a, \quad (9.10)$$

其中 $|\partial a|$ 为函数节点 a 的度. 由式 (9.4)、(9.5) 得

$$f = \sum_i \frac{\langle \Delta F_i e^{-y\Delta F_i} \rangle}{\langle e^{-y\Delta F_i} \rangle} - \sum_a (|\partial a| - 1) \frac{\langle \Delta F_a e^{-y\Delta F_a} \rangle}{\langle e^{-y\Delta F_a} \rangle}, \quad (9.11)$$

$$\Sigma = y(f - \phi). \quad (9.12)$$

平均场自旋玻璃模型可分为两类. 第一类是 SK 模型，低温相由态的超度量层级，即完全复制对称破缺（fRSB）描述. 向自旋玻璃相的转变是二级的，并伴随关联长度发散. 第二类是 $p > 2$ 的 p -自旋模型或不连续玻璃模型 [5]. 在 Ehrenfest 意义上，转变仍为二级（无潜热），但 Edwards–Anderson 序参量等在转变处跳跃，具有一级转变特征；

自旋玻璃理论称其为随机一级转变 [6]. 1RSB 对球约束连续自旋的 p -自旋球模型是正确的 [7, 8]; 但一般 Ising p -自旋模型在极低温可能具有 fRSB 结构 [9]. 结构玻璃⁴和约束满足问题等许多复杂系统都属于此类, 并共享许多性质 [4, 6, 10].

典型不连续自旋玻璃模型存在最大自由能 $f_{\max}$, $\Sigma(f_{\max})$ 决定困住大多数局域算法 (例如模拟退火 [11]) 的亚稳态数, 即阈值态. 另一端 $\Sigma(f_{\text{gs}}) = 0$ 给出自由能为 f_{gs} 的基态下界估计, 对应 1RSB 层次 $\Phi(y)$ 的极大值. 但在 Gardner 能量 f_G 以上, 1RSB 方案失稳, 须假定嵌套态层级的 fRSB 方案. 经典例子是 Ising p -自旋玻璃: 它先在较高温从顺磁相不连续地转变到 1RSB 相, 温度继续降至 Gardner 温度时, 再连续转变到 fRSB 相 [5]. 此外 $f_{\text{gs}} \leq f_G \leq f_{\max}$ [12].

9.2 在约束满足问题中的应用

在 1RSB 层次, 腔方法可按热力学概率测度的关注点分为两类. 第一类是能量腔方法 [13]. 把重加权参数写为 $y = \beta m$, 有

$$-\beta m \phi(\beta, m) = \max_{s, \epsilon} \{ \Sigma(s, \epsilon) + m(s - \beta \epsilon) \}, \quad (9.13)$$

其中 s, ϵ 分别是熵密度与能量密度. 取 $\beta \rightarrow \infty$ 、 $m \rightarrow 0$ 而保持 y 有限:

$$\phi(y) = \max_{\epsilon} \{ \Sigma(\epsilon) - y \epsilon \}. \quad (9.14)$$

$\beta \rightarrow \infty$ 是优化问题中寻找模型基态的零温极限; $\Sigma(\epsilon)$ 决定能量密度为 ϵ 的构型簇数, 其零点还确定 SAT 阈值, 例如随机 K -SAT 问题.

约束满足问题中, 每个解可视为传统统计力学模型的平衡构型. 解可组成指数多个簇 [14], 每个簇可称为纯态, 故其统计可由 1RSB 捕捉. 在存在满足全部 Boolean 约束的解、基态能量保持为零的 SAT 区域, 最优 $y \rightarrow \infty$; 从下方跨过 SAT 阈值后, 最优 y 立即成为有限值 [15].

在 $y \rightarrow \infty$ (亦即 $m = 0$) 时, 能量腔方法使 Gibbs 测度集中于能量为零的基态 (SAT 构型), 从而得到随机 K -SAT 的高效完全分布式算法—调查传播 [13]. 标准 BP 在约束密度超过某个仍低于 SAT 阈值的阈值后失效, 而调查传播明确纳入簇间涨落, 给出随机选取一个簇并发现某变量在该簇内冻结于某一方向的精确概率 [13]. 因而它能在典型情形下求解 NP 困难问题⁵, 直至十分接近 SAT 阈值. 但由于解簇中的冻结效应, 它不能处理随机 K -XOR-SAT [16]; 对基态能量非零的优化问题, 计算复杂度也很高.

若只关注 SAT 区域 $\epsilon = 0$, 则转向熵部分:

$$\Sigma(\epsilon = 0) = \max_s \Sigma(s, \epsilon = 0) = \Sigma(m = 0). \quad (9.15)$$

即能量型 $m = 0$ 腔方法计算典型或数量最多的簇的复杂度, 各簇不论大小均等权重; 这也可由 $\partial \Sigma(s) / \partial s = -m$ 看出. 推广到熵腔方法:

$$\phi(m) = \max_s \{ \Sigma(s) + m s \}, \quad (9.16)$$

⁴许多相互作用粒子运动时, 每个粒子具有局域随机环境.

⁵NP 类是否不同于可在多项式时间求解的 P 类, 仍是数学中的公开问题.

Legendre 变换给出

$$s = \frac{\partial \phi(m)}{\partial m}, \quad \Sigma(s) = \phi(m) - ms. \quad (9.17)$$




图 9.2: Parisi 参数与态复杂度的示意图. α 表示约束满足问题的约束密度, 即每个自由度的约束数.

鞍点近似容易导出 $m = -\partial \Sigma(s)/\partial s$. 给定 m 选择态 (或簇) 的大小, 正如 RS 层次温度选择构型. 检查模型是否出现 1RSB 解的首要测试, 是验证 $m = 1$ 时是否出现非平凡解 (图 9.2). 在相应阈值处, 点到集合关联函数 [14]—随机选取变量与距其一定距离的变量集合间的平均关联—在不连续转变时不连续出现, 在连续转变时连续出现. 该阈值称为动力学转变点 α_d . 热力学相关、熵占优的簇 ($m = 1$) 占据优势, 因而许多每步只改变少量变量的局域算法受此转变影响. 连续 1RSB 转变时, RS 解的局域稳定性阈值与动力学阈值严格重合; 不连续转变时, 局域失稳发生在转变之后 [14]. 动力学转变处发生非平凡遍历性破缺, 此后无法均匀抽取解或平衡构型.

继续增大约束密度, 到凝聚阈值 α_c 时热力学 m 开始下降 (图 9.2). Gibbs 测度凝聚在少数或数量随自由度次指数增长的簇上, 平衡 m 由 $\Sigma(m_{\text{eq}}) = 0$ 确定. 依具体问题, 还可能出现冻结转变: 热力学占优簇含有有限比例的变量冻结于相同指定方向 [16]. α_f 处的冻结转变形成算法壁垒, 因为从一个簇转到另一个簇需要大规模重排变量. 例如随机 K -XOR-SAT 中 $\alpha_d = \alpha_f$, 所有簇大小相同; 随机 3-SAT 中 $\alpha_c = \alpha_d$.

1RSB 相中, 腔边缘概率随态 (簇) 涨落. 一般 1RSB 方程可紧凑写为

$$P(m_{i \rightarrow a}) = \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \int d\hat{m}_{b \rightarrow i} \delta[m_{i \rightarrow a} - \mathcal{F}(\{\hat{m}_{b \rightarrow i}\})] Z_{i \rightarrow a}^m. \quad (9.18)$$

RS 消息 $m_{i \rightarrow a}$ 现变为概率函数, 即态间消息的调查; $\mathcal{F}$ 是每个态内成立的 RS 迭代. 腔配分函数以幂 m 加权, 对应 Monte Carlo 统计权重 $e^{-\beta m \Delta F_{i \rightarrow a}}$, 抑制进入高自由能态 [17, 18]. 1RSB 迭代可由 1RSB 自由能 $\Phi(\beta, m)$ 关于函数序参量 (消息上的概率测度) 以及 Parisi 参数 m 或 y 的变分原理导出 [19, 20]. 若 $P(m_{i \rightarrow a})$ 不集中于少数孤立值, 就不能用少量实数参数化, 也无法导出调查传播那样的高效算法.

$m = 1$ 的特殊情形显著简化复杂 1RSB 方程, 使使用布居动力学数值求解的成本大幅降低 [14, 17, 19]. 布居动力学用一组不断更新的随机变量表示概率分布, 特别适合求

解递归概率函数形式的 1RSB 方程. 此时

$$\phi(\beta, m = 1) = -\frac{\Sigma(s, \epsilon) + s}{\beta} = -T s_{\text{tot}}. \quad (9.19)$$

在 $\Sigma(m = 1) > 0$ 的动力学 1RSB 区域, RS 边缘概率与自由能仍渐近精确; 正确总熵只在凝聚相及其后的相中偏离 RS 值, 更具体地 $s_{\text{tot}} = s^* < s_{\text{RS}}$, 且 $\Sigma(s^*) = 0$ [4]. 因此动力学转变并非真正热力学转变. 当 $\Sigma(m)$ 消失时, 发生真正或理想玻璃转变, 即 Kauzmann 转变 [21]; 自由能二阶导数在此不连续.

随机能量模型和二值感知机学习问题等系统存在冻结相 [22, 23]. 对第 α 个态, 若 $f_\alpha = \epsilon_\alpha$, 则

$$e^{-N\beta m \phi(\beta, m)} = \sum_{\alpha} e^{-N\beta m f_\alpha} = \sum_{\alpha} e^{-N\beta m \epsilon_\alpha} = e^{-N\beta m f_{\text{RS}}(\beta m)}. \quad (9.20)$$

定义熵消失的逆温 β_s , 满足 $s_{\text{RS}}(\beta_s) = 0$. 当 $\beta = \beta_s$ 时 $m = \beta_s/\beta = 1$; 温度继续降低 (m 也降低) 时, 自由能被钳制在零熵值, 如随机能量模型. 这类模型用零熵条件解决熵危机, 即自由能在有限温度取极大值 [18, 24]. RS 失稳通常发生在熵危机之后, 因此在零熵点之前或恰在该点必存在不连续转变 [25].

9.3 更多步复制对称破缺

当系统出现长程关联, 例如点到集合关联不衰减为零时, RS 解可能不正确 [26], 这是充分条件. 正确 RS 解的必要条件是自旋玻璃磁化率不发散:

$$\chi_{\text{SG}} = \frac{1}{N} \sum_{i,j} \overline{(\langle \sigma_i \sigma_j \rangle - \langle \sigma_i \rangle \langle \sigma_j \rangle)^2}, \quad (9.21)$$

尖括号为热平均, 上横线为对模型参数的无序平均. 条件不满足时须引入 1RSB 等更高层次近似; 换言之, 小扰动会打破复制对称, 这与复制空间中在对称序参量附近作扰动分析的 de Almeida–Thouless (AT) 稳定性分析一致 [27].

若 1RSB 解在分布或消息的小变化下继续失稳 (例如 Gardner 温度处), 则需要更多层 RSB. 一般 2RSB 理论的序参量是“分布的分布”; 相应地, 态可聚合成不同簇 (态间磁化率发散), 或每个态进一步分裂 (态内磁化率发散) [25]. 这些磁化率取决于如何以 Boltzmann 权重对各态平均.

复制理论中的重叠矩阵可解释为纯态 a, b 间的重叠矩阵 [28, 29, 30, 31]:

$$Q_{ab} = \frac{1}{N} \sum_i \langle \sigma_i \rangle_a \langle \sigma_i \rangle_b, \quad (9.22)$$

其中 $\langle \cdot \rangle_a$ 表示态 a 内的热平均. 在 Parisi 设定中, 1RSB 把 n 个副本分为 n/m_1 个大小为 m_1 的相同簇, 每个簇内仍保持副本置换对称. 1RSB 因而需要两个序参量 $q_0 < q_1$. 一般 k 步 RSB 满足 $1 = m_{k+1} < m_k < \dots < m_0 = n$: 每增加一层, 对角块进一步分为 m_i/m_{i+1} 个子块, 并给每块赋值 q_{i+1} (图 9.3). 数学上

$$Q_{ab} = q_i, \quad \text{若} \quad \left\lfloor \frac{a}{m_i} \right\rfloor = \left\lfloor \frac{b}{m_i} \right\rfloor, \quad \left\lfloor \frac{a}{m_{i+1}} \right\rfloor \neq \left\lfloor \frac{b}{m_{i+1}} \right\rfloor, \quad (9.23)$$

the system, e.g., the point-to-set correlation does not decay to zero [26]. This is also called the sufficient condition. A necessary condition for the correct RS solution is the non-divergence of the spin glass susceptibility χ_{SG} , defined as

$$\chi_{SG} = \frac{1}{N} \sum_{i,j} \overline{(\langle \sigma_i \sigma_j \rangle - \langle \sigma_i \rangle \langle \sigma_j \rangle)^2}, \quad (9.21)$$

where the angular brackets mean the thermal average and the overline means the disordered average over model parameters. When these conditions are not satisfied, high levels of approximation must be introduced, e.g., 1RSB, in other words, a small perturbation breaks the replica symmetry, in accord with the (de Aleida-Thouless) AT stability analysis within the replica scheme [27], i.e., via a perturbation analysis in the replica space around the symmetric order parameters. If the 1RSB solution is

图 9.3: 采用更高层次近似时重叠矩阵变化的示意图. n 是副本数, m_i 是复制对称破缺层级中子块的大小.

$[x]$ 表示不大于 x 的最大整数. $\{q_i\}$ 构成表示相空间层级组织中态相似性的序列; 不同块间副本的置换对称显然被打破. 解析延拓到 $n \rightarrow 0$ 后, 关系变为 $0 = m_0 < m_1 < \dots < m_{k+1} = 1$.

反映 RSB 效应的可观测测度是依无序实现而定的分布

$$P_J(q) = \sum_{a,b} \omega_a \omega_b \delta(q_{ab} - q), \quad (9.24)$$

其中 J 表示模型无序, ω_a 是态 a 的统计权重. 该分布不是自平均的, 其形状依赖具体模型实现; 这不同于自由能, 后者的涨落随系统规模增加而减小, 使单实例自由能近似复制理论给出的典型值.

再取 $k \rightarrow \infty$, 得到 fRSB 解, 此时 q_i 变为连续函数 $q(x)$, 范围 $q \in [0, q_{\max}]$. fRSB 相中纯态按超度量结构组织, 且 Edwards–Anderson 序参量 $q_{EA} = \max_x q(x)$. 反函数 $x(q)$ 就是累积分布

$$x(q) = \int_0^q dq' P(q'), \quad (9.25)$$

给出观测到不大于 q 的重叠的概率, 故 $0 \leq x \leq 1$, 并有 $P(q) = \overline{P_J(q)} = dx(q)/dq$. 这样便可把副本的层级聚类解释为纯态的物理图像. 受限 Boltzmann 机的机器学习模型中也研究了 RSB 效应并发现态空间的超度量结构 [32]. 三个态间重叠的超度量性质意味着两个较小重叠相等 [1].

最后指出, 复制理论中 1RSB 自由能总高于 RS 自由能; 随着 RSB 层数增加, 真实自由能的下界得到改善 [33, 34]. Parisi 提出的 SK 模型 fRSB 解已经获得数学严格证明 [35].

参考文献

- [1] M. Mézard, G. Parisi, and M. A. Virasoro, *Spin Glass Theory and Beyond* (World Scientific, Singapore, 1987).

- [2] J. Ardelius and L. Zdeborová, Phys. Rev. E 78, 040101 (2008).
- [3] R. Monasson, Phys. Rev. Lett. 75(15), 2847 (1995).
- [4] M. Mézard and A. Montanari, *Information, Physics, and Computation* (Oxford University Press, Oxford, 2009).
- [5] E. Gardner, Nucl. Phys. B 257(6), 747 (1985).
- [6] M. Mézard, Physica A 306, 25 (2002).
- [7] A. Crisanti and H. J. Sommers, Z. Phys. B 87(3), 341 (1992).
- [8] A. Crisanti, H. Horner, and H. J. Sommers, Z. Phys. B 92(2), 257 (1993).
- [9] A. Montanari and F. Ricci-Tersenghi, Eur. Phys. J. B 33(3), 339 (2003).
- [10] V. Lubchenko, Adv. Phys. 64(3), 283 (2015).
- [11] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, Science 220(4598), 671 (1983).
- [12] A. Crisanti, L. Leuzzi, G. Parisi, and T. Rizzo, Phys. Rev. Lett. 92(12), 127203 (2004).
- [13] M. Mézard, G. Parisi, and R. Zecchina, Science 297(5582), 812 (2002).
- [14] A. Montanari, F. Ricci-Tersenghi, and G. Semerjian, J. Stat. Mech. 2008, P04004 (2008).
- [15] M. Mézard and R. Zecchina, Phys. Rev. E 66(5), 056126 (2002).
- [16] G. Semerjian, J. Stat. Phys. 130(2), 251 (2007).
- [17] H. Zhou, Phys. Rev. E 77, 066102 (2008).
- [18] H. Huang, Commun. Theor. Phys. 63(1), 115 (2015).
- [19] M. Mézard and G. Parisi, Eur. Phys. J. B 20, 217 (2001).
- [20] F. Concetti, arXiv:1911.00557 (2019).
- [21] W. Kauzmann, Chem. Rev. 43(2), 219 (1948).
- [22] W. Krauth and M. Mézard, J. Phys. 50(20), 3057 (1989).
- [23] H. Huang and Y. Kabashima, Phys. Rev. E 90, 052813 (2014).
- [24] O. C. Martin, M. Mézard, and O. Rivoire, J. Stat. Mech. 2005(9), P09006 (2005).
- [25] O. Rivoire, G. Biroli, O. C. Martin, and M. Mézard, Eur. Phys. J. B 37, 55 (2004).

- [26] M. Mézard and A. Montanari, J. Stat. Phys. 124(6), 1317 (2006).
- [27] J. R. L. de Almeida and D. J. Thouless, J. Phys. A 11(5), 983 (1978).
- [28] G. Parisi, Phys. Lett. A 73(3), 203 (1979).
- [29] G. Parisi, Phys. Rev. Lett. 43(23), 1754 (1979).
- [30] G. Parisi, J. Phys. A 13(3), 1101 (1980).
- [31] G. Parisi, J. Phys. A 13, L115 (1980).
- [32] G. S. Hartnett, E. Parker, and E. Geist, Phys. Rev. E 98, 022116 (2018).
- [33] F. Guerra, Commun. Math. Phys. 233(1), 1 (2003).
- [34] S. Franz and M. Leone, J. Stat. Phys. 111, 535 (2003).
- [35] M. Talagrand, Ann. Math. 163(1), 221 (2006).

受限 Boltzmann 机的统计力学

基于能量的模型是一类典型生成模型，能学习数据的任意分布，并产生服从原数据分布的新样本。本章介绍两种基于能量的模型：Boltzmann 机 (BM) 与受限 Boltzmann 机 (RBM)。我们介绍最大化对数似然的学习方法并分析 RBM 的统计力学；利用 Bethe 近似计算 RBM 自由能，再导出磁化强度和隐层-可见层关联等与学习有关的热力学量，为训练连续权重 RBM 提供另一种高效方法。本章还介绍一种受物理启发的强大算法，用来训练曾被认为难以处理的离散权重 RBM[6]。RBM 训练在深度学习早期发展中发挥了重要作用 [10]。

10.1 Boltzmann 机

Boltzmann 机 (Boltzmann machine, BM) 是图 10.1 所示的基于能量模型。它是无监督学习网络，能量为

$$E(\boldsymbol{\sigma}) = - \sum_i h_i \sigma_i - \sum_{i < j} w_{ij} \sigma_i \sigma_j, \quad (10.1)$$

其中 $\sigma_i = \pm 1$ 为节点 i 的状态， h_i 为偏置， w_{ij} 为节点 i, j 间的连接权重。构型服从 Boltzmann 分布

$$p(\boldsymbol{\sigma}) = \frac{1}{Z} e^{-\beta E(\boldsymbol{\sigma})}, \quad (10.2)$$

其中 $Z = \sum_{\boldsymbol{\sigma}} e^{-\beta E(\boldsymbol{\sigma})}$ 。用 BM 学习给定数据集即逆 Ising 问题（见第 3 章）。

Hopfield 模型可看作 $h_i = 0$ 且耦合按 Hebb 规则构造的特殊 BM。一般而言，Hebb 规则不足以学习任意数据分布。给定含 M 个构型的数据集 $\{\boldsymbol{\sigma}^1, \dots, \boldsymbol{\sigma}^M\}$ ，通过最大化数据对数似然更新 BM 权重：

$$\begin{aligned} \mathcal{L}(\boldsymbol{\theta} | \{\boldsymbol{\sigma}\}) &= \langle \ln p_{\boldsymbol{\theta}}(\boldsymbol{\sigma}) \rangle_{\text{data}} \\ &= -\langle E(\boldsymbol{\sigma}, \boldsymbol{\theta}) \rangle_{\text{data}} - \ln Z(\boldsymbol{\theta}) \\ &= \sum_i h_i \langle \sigma_i \rangle_{\text{data}} + \sum_{i < j} w_{ij} \langle \sigma_i \sigma_j \rangle_{\text{data}} - \ln Z(\boldsymbol{\theta}). \end{aligned} \quad (10.3)$$

这里 $\langle \cdot \rangle_{\text{data}}$ 表示数据平均， $\boldsymbol{\theta} = \{\mathbf{W}, \mathbf{h}\}$ ，并令 $\beta = 1$ ，因为它可吸收到权重与偏置中。

梯度为

$$\frac{\partial \mathcal{L}}{\partial h_i} = \langle \sigma_i \rangle_{\text{data}} - \langle \sigma_i \rangle_{\text{model}}, \quad (10.4a)$$

$$\frac{\partial \mathcal{L}}{\partial w_{ij}} = \langle \sigma_i \sigma_j \rangle_{\text{data}} - \langle \sigma_i \sigma_j \rangle_{\text{model}}, \quad (10.4b)$$

$\langle \cdot \rangle_{\text{model}}$ 是模型测度下的热平均. 梯度上升更新为

$$\Delta h_i = \eta (\langle \sigma_i \rangle_{\text{data}} - \langle \sigma_i \rangle_{\text{model}}), \quad (10.5a)$$

$$\Delta w_{ij} = \eta (\langle \sigma_i \sigma_j \rangle_{\text{data}} - \langle \sigma_i \sigma_j \rangle_{\text{model}}), \quad (10.5b)$$

其中 η 为学习率. 数据平均容易计算, 但模型平均不可处理, 因为配分函数计算复杂度为 $O(2^N)$. 实践中可用 Monte Carlo 近似; 也可用第 3 章的平均场理论计算 $\langle \sigma_i \rangle_{\text{model}}$, 再由线性响应

$$\frac{\partial \langle \sigma_i \rangle_{\text{model}}}{\partial h_j} = \langle \sigma_i \sigma_j \rangle_{\text{model}} - \langle \sigma_i \rangle_{\text{model}} \langle \sigma_j \rangle_{\text{model}}$$

得到二点关联.




图 10.1: (a) 无隐藏节点的 BM; (b) 有隐藏节点的 BM.

标准 BM 也可引入隐藏节点, 提供可见节点 (其数目等于数据样本维数) 的潜在编码, 如图 10.1(b). 但学习涉及隐藏节点参数通常计算量很大, 因为需要 Monte Carlo 抽取隐藏节点状态. 这一障碍促成了受限 Boltzmann 机架构: 移除可见节点之间以及隐藏节点之间的连接, 从而显著降低计算成本 [1, 3].

10.2 受限 Boltzmann 机

RBM 架构如图 10.2. 隐藏节点编码感觉输入; 网络含一个隐藏层和一个可见层, 只允许层间连接而无层内连接. 对含 N 个可见节点和 M 个隐藏节点的 RBM, 学习试图最小化的能量为

$$E(\boldsymbol{\sigma}, \boldsymbol{s}) = - \sum_{i,a} \sigma_i w_{ia} s_a - \sum_i \phi_i \sigma_i - \sum_a h_a s_a, \quad (10.6)$$

σ_i 是偏置为 ϕ_i 的可见节点状态, s_a 是偏置为 h_a 的隐藏节点状态, w_{ia} 是二者的连接. 网络状态服从

$$p(\boldsymbol{\sigma}, \mathbf{s}) = \frac{1}{Z} e^{-\beta E(\boldsymbol{\sigma}, \mathbf{s})}, \quad (10.7)$$

其中 $Z = \sum_{\boldsymbol{\sigma}, \mathbf{s}} e^{-\beta E(\boldsymbol{\sigma}, \mathbf{s})}$, 并令 $\beta = 1$. 由于无横向连接, 同层节点条件独立:

$$p(\sigma_i | \mathbf{s}) = \frac{1}{1 + \exp[-2\sigma_i(\phi_i + \sum_a w_{ia}s_a)]}, \quad (10.8a)$$

$$p(s_a | \boldsymbol{\sigma}) = \frac{1}{1 + \exp[-2s_a(h_a + \sum_i w_{ia}\sigma_i)]}. \quad (10.8b)$$




Fig. 10.2 Schematic illustration of a RBM. The RBM has one hidden layer and one visible layer. Connections are only allowed between layers. The recognition process is defined as sampling hidden

图 10.2: RBM 示意图. 网络含一个隐藏层和一个可见层, 只允许层间连接. 给定可见态抽取隐藏态称为识别过程; 给定隐藏态抽取可见态称为重构过程.

给定可见节点状态, 可容易地抽取隐藏节点状态, 称为识别过程; 反过程称为重构. 与 BM 类似, RBM 权重由最大化数据对数似然学习. 给定数据集 $\{\boldsymbol{\sigma}^1, \dots, \boldsymbol{\sigma}^M\}$,

$$\mathcal{L}(\boldsymbol{\theta} | \{\boldsymbol{\sigma}\}) = \langle \ln p_{\boldsymbol{\theta}}(\boldsymbol{\sigma}) \rangle_{\text{data}} = -\langle E(\boldsymbol{\sigma}, \boldsymbol{\theta}) \rangle_{\text{data}} - \ln Z(\boldsymbol{\theta}), \quad (10.9)$$

$\boldsymbol{\theta} = \{\mathbf{W}, \boldsymbol{\phi}, \mathbf{h}\}$. 梯度为

$$\frac{\partial \mathcal{L}}{\partial w_{ia}} = \langle \sigma_i s_a \rangle_{\text{data}} - \langle \sigma_i s_a \rangle_{\text{model}}, \quad (10.10a)$$

$$\frac{\partial \mathcal{L}}{\partial \phi_i} = \langle \sigma_i \rangle_{\text{data}} - \langle \sigma_i \rangle_{\text{model}}, \quad (10.10b)$$

$$\frac{\partial \mathcal{L}}{\partial h_a} = \langle s_a \rangle_{\text{data}} - \langle s_a \rangle_{\text{model}}. \quad (10.10c)$$

模型平均仍需 $O(2^{N+M})$ 复杂度. 常用高效方法是对比散度 (CD) 算法 [4]: 从数据样本出发, 按式 (10.8) 交替 Gibbs 抽样; 为节省时间, 通常截断到少数步, 例如一步.

以下将说明, 可用 Bethe 近似解析得到模型平均与自由能, 从而理解 RBM 的统计力学 [5]. 为简化, 考虑随机 RBM: 所有 w_{ia} 独立同分布于均值为零、方差为 g/N 的 Gaussian 分布; 两层偏置也独立同分布于均值为零、方差为 v 的 Gaussian 分布.

10.3 自由能计算

利用条件独立性，可导出可见节点边缘概率的精确形式：

$$\begin{aligned} p(\boldsymbol{\sigma}) &= \sum_{\mathbf{s}} p(\boldsymbol{\sigma}, \mathbf{s}) \\ &= \frac{1}{Z} \prod_i e^{\beta \sigma_i \phi_i} \prod_a [2 \cosh(\beta \mathbf{w}_a \boldsymbol{\sigma} + \beta h_a)], \end{aligned} \quad (10.11)$$

$\mathbf{w}_a$ 是连接到隐藏节点 a 的权重向量. 直接计算 Z 需 $O(2^N)$, 可用 Bethe 近似作第一层自由能近似. 边缘化后的系统可由因子图表示: 变量节点为 σ_i , 因子节点为 $2 \cosh(\beta \mathbf{w}_a \boldsymbol{\sigma} + \beta h_a)$, 对应第 3 章的 $f_a(\mathbf{x}_a)$. 以下仍令 $\beta = 1$.




Fig. 10.3 Factor graph representation of a RBM. Circles denote variable nodes and squares denote factor nodes

图 10.3: RBM 的因子图表示. 圆为变量节点, 方形为因子节点.

引入腔概率 $P_{i \rightarrow a}(\sigma_i)$, 表示移除因子节点 a 时变量节点 i 的状态概率; 再引入辅助量 $\mu_{b \rightarrow i}$, 表示把变量节点 i 固定为 σ_i 时因子节点 b 的贡献. BP 方程为

$$P_{i \rightarrow a}(\sigma_i) = \frac{1}{Z_{i \rightarrow a}} e^{\phi_i \sigma_i} \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(\sigma_i), \quad (10.12a)$$

$$\mu_{b \rightarrow i}(\sigma_i) = \sum_{\{\sigma_j : j \in \partial b \setminus i\}} 2 \cosh(\mathbf{w}_b \boldsymbol{\sigma} + h_b) \prod_{j \in \partial b \setminus i} P_{j \rightarrow b}(\sigma_j). \quad (10.12b)$$

其中

$$Z_{i \rightarrow a} = e^{\phi_i} \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(+1) + e^{-\phi_i} \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(-1).$$

但第二式的求和仍需 $O(2^{N-1})$.

$\mu_{b \rightarrow i}$ 是 Boltzmann 因子 $2 \cosh(\mathbf{w}_b \boldsymbol{\sigma} + h_b)$ 对 $\{\sigma_j : j \in \partial b \setminus i\}$ 的平均. Bethe 近似下, 给定腔概率后, 因子节点周围的 σ_j 近似独立. 因 $U_{b \rightarrow i} = \sum_{j \in \partial b \setminus i} w_{jb} \sigma_j$ 是 $N-1$ 个近似独立变量之和, 中心极限定理表明大 N 时它服从 Gaussian 分布, 其均值与方差为

$$G_{b \rightarrow i} = \langle U_{b \rightarrow i} \rangle = \sum_{j \in \partial b \setminus i} w_{jb} m_{j \rightarrow b}, \quad (10.13a)$$

$$\Xi_{b \rightarrow i}^2 = \langle U_{b \rightarrow i}^2 \rangle - \langle U_{b \rightarrow i} \rangle^2 \simeq \sum_{j \in \partial b \setminus i} w_{jb}^2 (1 - m_{j \rightarrow b}^2), \quad (10.13b)$$

其中 $m_{j \rightarrow b} = \sum_{\sigma_j} \sigma_j P_{j \rightarrow b}(\sigma_j)$. 这里还按弱关联态假定 (与 RS 设定同一精神) 对方差作对角近似, 只计算关联矩阵的对角元之和. 于是

$$\begin{aligned}\mu_{b \rightarrow i}(\sigma_i) &= 2 \int Dt \cosh(G_{b \rightarrow i} + \Xi_{b \rightarrow i} t + h_b + w_{ib} \sigma_i) \\ &= 2e^{\Xi_{b \rightarrow i}^2/2} \cosh(G_{b \rightarrow i} + h_b + w_{ib} \sigma_i).\end{aligned}\quad (10.14)$$

代入腔概率, 得到腔磁化强度

$$m_{i \rightarrow a} = \tanh \left(\phi_i + \sum_{b \in \partial i \setminus a} u_{b \rightarrow i} \right), \quad (10.15a)$$

$$u_{b \rightarrow i} = \frac{1}{2} \ln \frac{\mu_{b \rightarrow i}(+1)}{\mu_{b \rightarrow i}(-1)} = \frac{1}{2} \ln \frac{\cosh(h_b + G_{b \rightarrow i} + w_{ib})}{\cosh(h_b + G_{b \rightarrow i} - w_{ib})}. \quad (10.15b)$$

$m_{i \rightarrow a}$ 是变量节点到因子节点的消息, $u_{b \rightarrow i}$ 是反向消息. 迭代式 (10.15) 至不动点后, Bethe 自由能为

$$F = \sum_i F_i - (N-1) \sum_a F_a, \quad (10.16a)$$

$$F_i = -\ln Z_i = -\ln \left[e^{\phi_i} \prod_{b \in \partial i} \mu_{b \rightarrow i}(+1) + e^{-\phi_i} \prod_{b \in \partial i} \mu_{b \rightarrow i}(-1) \right], \quad (10.16b)$$

$$F_a = -\ln Z_a = -\ln \left[2e^{\Xi_a^2/2} \cosh(G_a + h_a) \right], \quad (10.16c)$$

其中 $\Xi_a^2 = \sum_{j \in \partial a} w_{ja}^2 (1 - m_{j \rightarrow a}^2)$, $G_a = \sum_{j \in \partial a} w_{ja} m_{j \rightarrow a}$. 图 10.4 给出 Bethe 近似自由能的实验结果.

10.4 与学习有关的热力学量

一旦 BP 方程收敛, 完整系统中的可见节点磁化强度为

$$m_i = \tanh \left(\phi_i + \sum_{b \in \partial i} u_{b \rightarrow i} \right). \quad (10.17)$$

隐藏节点的磁化强度则由条件概率 (10.8b) 求得:

$$\hat{m}_a = \int Dx \tanh \left(\sqrt{\tilde{\Xi}_a^2} x + \tilde{G}_a \right), \quad \tilde{G}_a = \sum_i w_{ia} m_i + h_a, \quad \tilde{\Xi}_a^2 = \sum_i w_{ia}^2 (1 - m_i^2). \quad (10.18)$$

这里仍采用对角近似. 学习规则还需要可见-隐藏关联

$$C_{ai} = \langle s_a \sigma_i \rangle = \left\langle \tanh \left(\sum_i \sigma_i w_{ia} + h_a \right) \sigma_i \right\rangle_{\sigma}. \quad (10.19)$$




图 10.4: 随机 RBM 的自由能密度 $f = F/N$, 误差棒为十次试验的标准差. (a) $N = 1000, g = 1, v = 0.05$ 时 f 随 $\alpha = M/N$; (b) $N = 20, g = 1, v = 0.05$ 时精确自由能 (枚举) 与 Bethe 近似的绝对差; (c) (b) 中 $\alpha = 0.6$ 的比较, 直线表示 $f_{BA} = f_{exact}$; (d) $N = 1000, v = 0.05, \alpha = 0.5$ 时 f 随 g ; (e) $N = 1000, g = 1, \alpha = 0.5$ 时 f 随 v .

为求它，先右乘权重矩阵：

$$[CW]_{ab} = \left\langle \tanh \left(\sum_i \sigma_i w_{ia} + h_a \right) \sum_j \sigma_j w_{jb} \right\rangle_{\sigma}. \quad (10.20)$$

令投影场的协方差为

$$\Omega_{ab} = \sum_{ij} w_{ia} w_{jb} \hat{C}_{ij}, \quad \hat{C}_{ij} = \langle \sigma_i \sigma_j \rangle - m_i m_j, \quad (10.21)$$

即矩阵形式

$$\Omega = \mathbf{W}^\top \hat{\mathbf{C}} \mathbf{W}. \quad (10.22)$$

在对角近似下，

$$\Omega_{ab} \simeq \delta_{ab} \sum_i w_{ia}^2 (1 - m_i^2). \quad (10.23)$$

把投影场近似为联合 Gaussian 变量并作分部积分，可得

$$[CW]_{ab} = \Omega_{ab} \int Dt \left[1 - \tanh^2 \left(\sqrt{\Omega_{aa}} t + \tilde{G}_a \right) \right] + \hat{m}_a \sum_i m_i w_{ib}. \quad (10.24)$$

定义

$$A_{aa} = \int Dt \left[1 - \tanh^2 \left(\sqrt{\Omega_{aa}} t + \tilde{G}_a \right) \right], \quad (10.25)$$

则

$$\mathbf{C} \mathbf{W} = \mathbf{A} \mathbf{W}^\top \hat{\mathbf{C}} \mathbf{W} + \hat{\mathbf{m}}^\top \mathbf{m} \mathbf{W}, \quad (10.26a)$$

$$\mathbf{C} = \mathbf{A} \mathbf{W}^\top \hat{\mathbf{C}} + \hat{\mathbf{m}}^\top \mathbf{m}. \quad (10.26b)$$

逐元素写作

$$C_{ai} = \hat{m}_a m_i + A_{aa} \sum_j w_{ja} \hat{C}_{ji}. \quad (10.27)$$

进一步使用对角近似，得到实用表达式

$$C_{ai} \simeq \hat{m}_a m_i + A_{aa} w_{ia} (1 - m_i^2). \quad (10.28)$$

因此，训练所需的三类模型平均可概括为

$$\langle \sigma_i \rangle_{\text{model}} = m_i, \quad (10.29a)$$

$$\langle s_a \rangle_{\text{model}} = \hat{m}_a, \quad (10.29b)$$

$$\langle s_a \sigma_i \rangle_{\text{model}} = \hat{m}_a m_i + A_{aa} w_{ia} (1 - m_i^2). \quad (10.29c)$$

Bethe 近似的复杂度为 $O(nMN)$ ，其中 n 是消息传递迭代次数；CD- k 的复杂度为 $O(kTMN)$ ，其中 T 是 Monte Carlo 样本数。因而在大样本训练中，Bethe 方法可明显节省计算。

10.5 稳定性分析

BP 不动点只有在微小消息扰动不随迭代增长时才可靠. 如图 10.5, 设 $m_{j \rightarrow b} \rightarrow m_{j \rightarrow b} + \delta m_{j \rightarrow b}$, 则一轮传播后

$$\begin{aligned} \delta_{m_{i \rightarrow a}}^2 &= \left(\sum_{b \in \partial i \setminus a} \sum_{j \in \partial b \setminus i} \frac{\partial m_{i \rightarrow a}}{\partial m_{j \rightarrow b}} \delta m_{j \rightarrow b} \right)^2 \\ &\simeq \sum_{b \in \partial i \setminus a} \sum_{j \in \partial b \setminus i} \left(\frac{\partial m_{i \rightarrow a}}{\partial m_{j \rightarrow b}} \right)^2 (\delta m_{j \rightarrow b})^2. \end{aligned} \quad (10.30)$$

第二行忽略不同扰动之间的关联. 以 $\mathcal{V}_{i \rightarrow a} = \delta_{m_{i \rightarrow a}}^2$ 表示扰动强度, 式 (10.15) 给出

$$\mathcal{V}_{i \rightarrow a} = \frac{(1 - m_{i \rightarrow a}^2)^2}{4} \sum_{b \in \partial i \setminus a} \mathcal{P}_{b \rightarrow i} [\tanh(\Gamma_{b \rightarrow i}) - \tanh(\Gamma_{b \rightarrow i} - 2w_{bi})]^2, \quad (10.31)$$

其中

$$\Gamma_{b \rightarrow i} = h_b + G_{b \rightarrow i} + w_{ib}, \quad \mathcal{P}_{b \rightarrow i} = \sum_{j \in \partial b \setminus i} w_{jb}^2 \mathcal{V}_{j \rightarrow b}. \quad (10.32)$$





Fig. 10.5 Propagation of message-perturbations through the factor graph of a RBM

图 10.5: 消息扰动在 RBM 因子图中的传播.

定义总方差 $S(t) = \sum_{(i,a)} \mathcal{V}_{i \rightarrow a}(t)$, 以及在达到预设最大迭代数的时刻 t^c 处的稳定性参数 $\lambda = S(t^c + 1)/S(t^c)$. 若 $\lambda > 1$, 总方差增长, 消息传递不稳定; 因此使用 Bethe 近似时应选择使 $\lambda \leq 1$ 的 g, α . 图 10.6 表明, 在 $N = 1000, \alpha = 0.5, v = 0.05$ 时, 系统在 $g \simeq 2.1$ 附近变得不稳定.



10.6 Stability analysis of random RBMs. The error bar is the standard deviation over 20 om realizations of the model. **a** Stability parameter λ versus g with $N = 1000$, $v = 0.05$ and $0.5 \leq \lambda$ increases with α . When $\alpha = 2.1$, λ is near to the critical point ($\lambda = 1$). Some instances

图 10.6: 随机 RBM 的稳定性分析. 误差棒为二十个随机实现的标准差. (a) $N = 1000, v = 0.05, \alpha = 0.5$ 时稳定性参数随 g ; (b) $N = 1000, v = 0.05, g = 1$ 时随 α ; (c) $N = 1000, v = 0.05, \alpha = 0.5, g = 2.1$ 时两个不稳定实例 (虚线) 与一个稳定实例 (实线) 中的 $S(t)/S(0)$.

10.6 训练二元 RBM 的变分平均场理论

连续权重 RBM 可通过对数似然的梯度上升训练；但在二元 RBM 中，直接对二元权重求导并无定义。本节引入最大化数据对数似然下界的变分原理，由此得到把消息传递与梯度上升相结合的新算法 [6]。

10.6.1 二元权重 RBM

考虑 N 个可见节点、 P 个隐藏节点以及 M 个训练样本。突触 $\xi_i^\mu = \pm 1$ ，原书给出的能量写为 $E(\boldsymbol{\sigma}, \mathbf{h}) = \sum_{i,\mu} \sigma_i \xi_i^\mu h_\mu$ 。边缘化隐藏节点后，

$$P(\boldsymbol{\sigma}) = \frac{1}{Z(\boldsymbol{\xi})} \prod_{\mu=1}^P \cosh(\beta X_\mu), \quad X_\mu = \frac{1}{\sqrt{N}} \boldsymbol{\xi}^\mu \cdot \boldsymbol{\sigma}. \quad (10.33)$$

数据集 $D = \{\boldsymbol{\sigma}^a\}_{a=1}^M$ 的似然为

$$P(D | \boldsymbol{\xi}) = \frac{1}{Z(\boldsymbol{\xi})^M} \prod_{a,\mu} \cosh(\beta X_\mu^a), \quad X_\mu^a = \frac{1}{\sqrt{N}} \boldsymbol{\xi}^\mu \cdot \boldsymbol{\sigma}^a. \quad (10.34)$$

由 Bayes 公式，突触的后验分布为

$$P(\boldsymbol{\xi} | D) = \frac{1}{\Omega} \exp \left[-M \ln Z(\boldsymbol{\xi}) + \sum_{a,\mu} \ln \cosh(\beta X_\mu^a) \right] P(\boldsymbol{\xi}), \quad (10.35)$$

其中

$$\Omega = \sum_{\boldsymbol{\xi}} P(\boldsymbol{\xi}) \exp \left[-M \ln Z(\boldsymbol{\xi}) + \sum_{a,\mu} \ln \cosh(\beta X_\mu^a) \right]. \quad (10.36)$$

直接计算后验仍不可处理。

10.6.2 变分原理

用可处理的分布 $q_\lambda(\boldsymbol{\xi})$ 近似后验。非负的 KL 散度满足

$$\text{KL}(q_\lambda(\boldsymbol{\xi}) \| P(\boldsymbol{\xi} | D)) = -\text{LB}(q_\lambda) + \ln P(D), \quad (10.37)$$

其中证据下界为

$$\text{LB}(q_\lambda) = -\text{KL}(q_\lambda(\boldsymbol{\xi}) \| P(\boldsymbol{\xi})) + \mathbb{E}_q[\ln P(D | \boldsymbol{\xi})]. \quad (10.38)$$

取因子化先验与变分分布

$$P(\boldsymbol{\xi}) = \prod_{i,\mu} \frac{1 + \xi_i^\mu m_{i\mu}}{2}, \quad (10.39a)$$

$$q_\lambda(\boldsymbol{\xi}) = \prod_{i,\mu} \frac{1 + \xi_i^\mu \lambda_{i\mu}}{2}. \quad (10.39b)$$

因此 $\lambda_{i\mu} = \langle \xi_i^\mu \rangle_q$, 并有

$$q_\lambda(\xi_i^\mu) = \frac{1 + \xi_i^\mu \lambda_{i\mu}}{2}. \quad (10.40)$$

代入似然,

$$\text{LB}(q_\lambda) = -\text{KL}(q_\lambda \| P) + \mathbb{E}_q \left[\sum_{a,\mu} \ln \cosh(\beta X_\mu^a) - M \ln Z(\boldsymbol{\xi}) \right]. \quad (10.41)$$

由中心极限定理, X_μ^a 与 X_μ 在 q_λ 下近似 Gaussian, 其均值与方差为

$$G_\mu^a = \frac{1}{\sqrt{N}} \sum_i \lambda_{i\mu} \sigma_i^a, \quad \Xi_\mu^2 = \frac{1}{N} \sum_i (1 - \lambda_{i\mu}^2), \quad (10.42a)$$

$$G_\mu = \frac{1}{\sqrt{N}} \sum_i \lambda_{i\mu} \sigma_i, \quad \Xi_\mu^2 = \frac{1}{N} \sum_i (1 - \lambda_{i\mu}^2). \quad (10.42b)$$

于是

$$\begin{aligned} \text{LB}(q_\lambda) = & -\text{KL}(q_\lambda \| P) + \sum_{a,\mu} \int Dz \ln \cosh(\beta G_\mu^a + \beta \Xi_\mu z_\mu) \\ & - M \int Dz \ln \sum_{\boldsymbol{\sigma}} \prod_{\mu} \cosh(\beta G_\mu + \beta \Xi_\mu z_\mu). \end{aligned} \quad (10.43)$$

下界的计算. 用 Monte Carlo 积分, 式 (10.43) 近似为

$$\begin{aligned} \text{LB}(q_\lambda) = & -\text{KL}(q_\lambda \| P) + \frac{1}{B_1} \sum_{a,\mu,s} \ln \cosh(\beta G_\mu^a + \beta \Xi_\mu z_\mu^s) \\ & - \frac{M}{B_2} \sum_s \ln \sum_{\boldsymbol{\sigma}} \prod_{\mu} \cosh(\beta G_\mu + \beta \Xi_\mu z_\mu^s). \end{aligned} \quad (10.44)$$

其中 z_μ^s 为第 s 个标准 Gaussian 随机数, B_1, B_2 为样本数. KL 项可解析计算:

$$-\text{KL}(q_\lambda \| P) = \sum_{x=\pm 1} \sum_{i,\mu} \left[S\left(\frac{1+x\lambda_{i\mu}}{2}, \frac{1+xm_{i\mu}}{2}\right) - S\left(\frac{1+x\lambda_{i\mu}}{2}, \frac{1+x\lambda_{i\mu}}{2}\right) \right], \quad S(z, y) = z \ln y. \quad (10.45)$$

第三项不可直接计算, 却等价于一族对偶连续权重 RBM 的平均; 其权重为 $\lambda/\sqrt{N}$, 隐藏偏置为 $\Xi_\mu z_\mu^s$, 如图 10.7.

对偶 RBM 的腔磁化强度与腔偏置为

$$m_{i \rightarrow \nu} = \tanh \left(\sum_{\mu \in \partial i \setminus \nu} u_{\mu \rightarrow i} \right), \quad (10.46a)$$

$$u_{\mu \rightarrow i} = \tanh^{-1} \left[\tanh(\beta \chi_{\mu \rightarrow i} + \beta H_\mu) \tanh \left(\frac{\beta \lambda_{i\mu}}{\sqrt{N}} \right) \right], \quad (10.46b)$$




图 10.7: 期望对数配分函数的计算. 对 $q_\lambda(\xi_i^\mu)$ 的平均等价于对偶 RBM 系统的对数配分函数平均; 其突触为 $\lambda/\sqrt{N}$, 隐藏偏置为 $\Xi_\mu z_\mu^s$.

其中 $\chi_{\mu \rightarrow i} = N^{-1/2} \sum_{j \in \partial \mu \setminus i} \lambda_{j\mu} m_{j \rightarrow \mu}$, $H_\mu = \Xi_\mu z_\mu^s$. BP 收敛后, Bethe 对数配分函数为

$$\ln Z = \sum_i F_i - (N-1) \sum_\mu F_\mu, \quad (10.47a)$$

$$F_i = \sum_{\mu \in \partial i} \left[\frac{\beta^2 \Lambda_{\mu \rightarrow i}^2}{2} + \ln \cosh \left(\beta \chi_{\mu \rightarrow i} + \beta H_\mu + \frac{\beta \lambda_{i\mu}}{\sqrt{N}} \right) \right] + \ln \left(1 + \prod_{\mu \in \partial i} e^{-2u_{\mu \rightarrow i}} \right), \quad (10.47b)$$

$$F_\mu = \frac{\beta^2 \Lambda_\mu^2}{2} + \ln \cosh(\beta \chi_\mu + \beta H_\mu), \quad (10.47c)$$

其中 $\Lambda_{\mu \rightarrow i}^2 = N^{-1} \sum_{j \in \partial \mu \setminus i} \lambda_{j\mu}^2 (1 - m_{j \rightarrow \mu}^2)$, $\Lambda_\mu^2 = N^{-1} \sum_{j \in \partial \mu} \lambda_{j\mu}^2 (1 - m_{j \rightarrow \mu}^2)$, $\chi_\mu = N^{-1/2} \sum_i \lambda_{i\mu} m_{i \rightarrow \mu}$.

梯度的计算. KL 项的梯度为

$$-\frac{\partial}{\partial \lambda_{i\mu}} \text{KL}(q_\lambda \| P) = \sum_{x=\pm 1} \frac{x}{2} \left(\ln \frac{1 + x m_{i\mu}}{1 + x \lambda_{i\mu}} - 1 \right). \quad (10.48)$$

数据项的梯度是

$$\begin{aligned} & \frac{\partial}{\partial \lambda_{i\mu}} \sum_{a,\mu} \int Dz \ln \cosh(\beta G_\mu^a + \beta \Xi_\mu z_\mu) \\ &= \frac{\beta}{B_1 \sqrt{N}} \sum_{a,s} \sigma_i^a \tanh(\beta G_\mu^a + \beta \Xi_\mu z_\mu^s) - \frac{\beta^2 \lambda_{i\mu}}{N B_1} \sum_{a,s} [1 - \tanh^2(\beta G_\mu^a + \beta \Xi_\mu z_\mu^s)]. \end{aligned} \quad (10.49)$$

期望对数配分函数的梯度为

$$\frac{\partial}{\partial \lambda_{i\mu}} \int Dz \ln \sum_{\sigma} \prod_{\mu} \cosh(\beta G_{\mu} + \beta \Xi_{\mu} z_{\mu}) = \frac{\beta}{\sqrt{N} B_2} \sum_s \left[C_{i\mu} - \frac{\lambda_{i\mu} z_{\mu}^s}{\sqrt{N} \Xi_{\mu}} \hat{m}_{\mu} \right]. \quad (10.50)$$

其中热平均取自对偶 RBM, 所需量为

$$m_i = \tanh \left(\sum_{\mu \in \partial i} u_{\mu \rightarrow i} \right), \quad (10.51a)$$

$$\hat{m}_{\mu} = \int Dz \tanh(\beta \tilde{\chi}_{\mu} + \beta H_{\mu} + \beta \tilde{\Lambda}_{\mu} z), \quad (10.51b)$$

$$C_{i\mu} = \hat{m}_{\mu} m_i + \frac{\beta \lambda_{i\mu}}{\sqrt{N}} (1 - m_i^2) A_{\mu}, \quad (10.51c)$$

$$A_{\mu} = 1 - \int Dz \tanh^2(\beta \tilde{\chi}_{\mu} + \beta H_{\mu} + \beta \tilde{\Lambda}_{\mu} z), \quad (10.51d)$$

其中 $\tilde{\chi}_{\mu} = N^{-1/2} \sum_i \lambda_{i\mu} m_i$, $\tilde{\Lambda}_{\mu}^2 = N^{-1} \sum_i \lambda_{i\mu}^2 (1 - m_i^2)$. 综上, 下界梯度为

$$\begin{aligned} \Delta_{i\mu} = & \sum_{x=\pm 1} \frac{x}{2} \left(\ln \frac{1 + x m_{i\mu}}{1 + x \lambda_{i\mu}} - 1 \right) + \frac{\beta}{B_1 \sqrt{N}} \sum_{a,s} \sigma_i^a \tanh(\beta G_{\mu}^a + \beta \Xi_{\mu} z_{\mu}^s) \\ & - \frac{\beta^2 \lambda_{i\mu}}{N B_1} \sum_{a,s} [1 - \tanh^2(\beta G_{\mu}^a + \beta \Xi_{\mu} z_{\mu}^s)] - \frac{M \beta}{\sqrt{N} B_2} \sum_s \left[C_{i\mu} - \frac{\lambda_{i\mu} z_{\mu}^s}{\sqrt{N} \Xi_{\mu}} \hat{m}_{\mu} \right]. \end{aligned} \quad (10.52)$$

学习规则为

$$\lambda_{i\mu}^{t+1} = \lambda_{i\mu}^t + \eta \Delta_{i\mu}. \quad (10.53)$$

最终以 $\boldsymbol{\xi} = \text{sign}(\boldsymbol{\lambda})$ 解码; 在统计推断中这也称为最大边缘后验 (MPM) 估计 [9].

10.6.3 实验

首先考察含 P 个隐藏节点的植入模型. 预先指定真实突触 $\boldsymbol{\xi}^*$, 再由 Gibbs 抽样生成数据集; 相邻可见构型之间需取足够长的采样间隔, 以保证合成样本的弱关联. 以重叠 $Q^{\mu} = N^{-1} \sum_i \xi_i^{\mu} \xi_i^{\mu,*}$ 衡量能否恢复真实突触; 由于模型概率具有反演对称性, 取其绝对值. 还须考虑 $P!$ 种隐藏单元置换.

图 10.8 表明, 即使两个真实感受野相关, 算法仍能工作; 近似下界随训练增长, 说明变分分布逐渐接近真实后验. 三比特结果见图 10.9. 不同数据密度下的二比特学习效果总结于图 10.10: 相关性降低了学习所需的数据量, 这将在第 12 章解析导出. 该方法也可用于 MNIST 等结构化数据, 见图 10.11.




Fig. 10.8 Training process of two-bit planted RBMs. The number of visible nodes $N = 100$, and the data density $\alpha = \frac{M}{N} = 5$. The x-axis denotes the training epoch. **a** The absolute overlap between decoded receptive field and ground-truth receptive field. $Q^\mu = \frac{1}{N} \sum_i \xi_i^\mu \xi_i^{\mu,*}$. $q = \frac{1}{N} \sum_i \xi_i^{1,*} \xi_i^{2,*}$ is the correlation of the ground-truth synapses. The algorithm works even when the ground-truth

图 10.8: 二比特植入 RBM 的训练过程. $N = 100$, 数据密度 $\alpha = M/N = 5$. (a) 解码感受野与真实感受野的绝对重叠; 真实突触相关为 $q = N^{-1} \sum_i \xi_i^{1,*} \xi_i^{2,*}$. (b) $q_\lambda(\xi)$ 与 $P(\xi)$ 的 KL 散度及腔近似下界; “密度”指相应物理量除以模型参数数目.




Fig. 10.9 Training process of three-bit planted RBMs. The number of visible nodes $N = 100$, and the data density $\alpha = 5$. **a** The absolute overlap between decoded receptive field and ground-truth

图 10.9: 三比特植入 RBM 的训练过程. $N = 100, \alpha = 5$. (a) 解码感受野与真实感受野的绝对重叠; (b) KL 散度与近似下界.




图 10.10: $N = 100$ 时不同 α 下的平均绝对重叠. 误差棒为十次试验在第 100 轮终止时的标准差. 相关程度 $q = 0.3$ 的突触只需较少样本便较易学习, 但阈值因有限尺寸而圆滑化.




图 10.11: 用二元突触 RBM 训练 MNIST. $N = 784, P = 100, M = 2000$. (a) $q_\lambda(\xi)$ 与 $P(\xi)$ 的 KL 散度; (b) 近似下界.

参考文献

- [1] P. Smolensky, in *Information Processing in Dynamical Systems: Foundations of Harmony Theory* (MIT Press, Cambridge, 1986), pp. 194–281.
- [2] Y. Freund and D. Haussler, Technical Report, Santa Cruz, CA, USA (1994).
- [3] G. Hinton, *Neural Comput.* **14**, 1771 (2002).
- [4] G. Hinton, *Neural Comput.* **14**, 1771 (2002).
- [5] H. Huang and T. Toyozumi, *Phys. Rev. E* **91**, 050101 (2015).
- [6] H. Huang, *Phys. Rev. E* **102**, 030301(R) (2020).
- [7] H. Huang, *J. Stat. Mech.: Theory Exper.* **2017**(5), 053302 (2017).
- [8] D. M. Blei, A. Kucukelbir, and J. D. McAuliffe, *J. Amer. Stat. Assoc.* **112**(518), 859 (2017).
- [9] H. Nishimori, *Statistical Physics of Spin Glasses and Information Processing: An Introduction* (Oxford University Press, Oxford, 2001).
- [10] Y. Bengio, P. Lamblin, D. Popovici, and H. Larochelle, in *Advances in Neural Information Processing Systems* (2007), pp. 153–160.

二元突触无监督学习的最简模型

从无标签数据中学习潜藏特征称为无监督学习. 人类和非人动物的大脑能用很少样本完成这类学习, 而标准机器学习算法往往需要大量样本. 因此, 理解样本数如何影响学习过程十分重要. 本章提出一个最简无监督学习模型, 以统计物理方式揭示神经网络内部的学习机制 [1, 2].

11.1 模型设定

本章模型建立在上一章分析的受限 Boltzmann 机 (RBM) 上. 如图 11.1, RBM 含接收输入的可见层和形成内部表征的隐藏层; 层间全连接, 层内无横向连接. 可见与隐藏神经元之间的对称突触就是网络从训练样本中学习的特征. 常用的 CD 等梯度方法含有嵌套复杂性, 难以解析研究, 因此这里改用 Bayesian 学习框架.




Fig. 11.1 Schematic illustration of a general restricted Boltzmann Machine. $(\sigma_1, \sigma_2, \dots, \sigma_N)$ is a

图 11.1: 一般 RBM 示意图. $(\sigma_1, \dots, \sigma_N)$ 为输入数据, $(h_1, \dots, h_p)$ 为隐藏表征, $(\xi_{11}, \dots, \xi_{pN})$ 编码学习到的特征.

采用教师-学生设定: 有限样本由图 11.2 所示仅含一个隐藏节点的简单 RBM 生成. 可见构型 σ 与隐藏态 h 的分量均取 ± 1 . 真实特征 ξ 的各分量也以相等概率取 ± 1 , 且

神经元无外场. 联合分布满足

$$P(\boldsymbol{\sigma}, h) \propto \exp \left[-\frac{\beta}{\sqrt{N}} E(\boldsymbol{\sigma}, h) \right], \quad E(\boldsymbol{\sigma}, h) = - \sum_i h \xi_i \sigma_i,$$

其中 $N^{-1/2}$ 是统计物理分析所需的尺寸缩放, β 为逆温度.




Fig. 11.2 Schematic illustration of a simple RBM with only one hidden node. $(\sigma_1, \sigma_2, \dots, \sigma_N)$ is

图 11.2: 仅含一个隐藏节点的简单 RBM. $(\sigma_1, \dots, \sigma_N)$ 为输入, h 为隐藏态, $(\xi_1, \dots, \xi_N)$ 编码真实特征; 箭头标出识别与重构方向.

对隐藏态求和, 得到

$$P(\boldsymbol{\sigma} | \boldsymbol{\xi}) = \frac{\cosh \left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^T \boldsymbol{\sigma} \right)}{\sum_{\boldsymbol{\sigma}} \cosh \left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^T \boldsymbol{\sigma} \right)}. \quad (11.1)$$

归一化可精确求得:

$$\begin{aligned} \sum_{\boldsymbol{\sigma}} \cosh \left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^T \boldsymbol{\sigma} \right) &= \frac{1}{2} \prod_i \sum_{\sigma_i} \left[e^{\beta \xi_i \sigma_i / \sqrt{N}} + e^{-\beta \xi_i \sigma_i / \sqrt{N}} \right] \\ &= 2^N \cosh^N \left(\frac{\beta}{\sqrt{N}} \right). \end{aligned} \quad (11.2)$$

由式 (11.1) 可用 Gibbs 抽样生成独立样本. 给定 M 个样本 $\{\boldsymbol{\sigma}^a\}_{a=1}^M$, Bayes 规则和均匀先验给出

$$P(\boldsymbol{\xi} | \{\boldsymbol{\sigma}^a\}) = \frac{P(\{\boldsymbol{\sigma}^a\} | \boldsymbol{\xi}) P(\boldsymbol{\xi})}{\sum_{\boldsymbol{\xi}} P(\{\boldsymbol{\sigma}^a\} | \boldsymbol{\xi}) P(\boldsymbol{\xi})} = \frac{1}{Z} \prod_a \cosh \left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^T \boldsymbol{\sigma}^a \right). \quad (11.3)$$

β 调节数据噪声: 大 β 意味着特征强, 少量样本即可揭示; 小 β 则需更多样本. 定义数据密度 $\alpha = M/N$. 下文省略后验对样本集的显式条件.

11.2 sMP 与 AMP 方程的推导

Bayesian 学习希望最大化后验，并以 $\hat{\xi}_i = \arg \max_{\xi_i} P_i(\xi_i)$ 作概率推断。定义推断特征与真实特征的重叠

$$q = \left[\frac{1}{N} \sum_i \xi_i^{\text{true}} \langle \xi_i \rangle \right],$$

尖括号为热平均，方括号为对不同真实特征的冻结无序平均。 $q = 0$ 表示样本不提供有效信息， $q = 1$ 表示完全恢复。为计算非平凡的边缘分布 P_i ，在因子图上采用弱关联的 Bethe 近似。定义移除样本约束 a 后的腔分布 $P_{i \rightarrow a}(\xi_i)$ ，则 BP 方程为

$$P_{i \rightarrow a}(\xi_i) = \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(\xi_i), \quad (11.4a)$$

$$\mu_{b \rightarrow i}(\xi_i) = \sum_{\{\xi_j: j \in \partial b \setminus i\}} \cosh\left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^T \boldsymbol{\sigma}^b\right) \prod_{j \in \partial b \setminus i} P_{j \rightarrow b}(\xi_j). \quad (11.4b)$$

$\mu_{b \rightarrow i}$ 是约束 b 对节点 i 的贡献。大 N 时中心极限定理把它化为 Gaussian 积分。令

$$G_{b \rightarrow i} = \frac{1}{\sqrt{N}} \sum_{j \in \partial b \setminus i} \sigma_j^b m_{j \rightarrow b}, \quad m_{i \rightarrow a} = \sum_{\xi_i} \xi_i P_{i \rightarrow a}(\xi_i),$$

得到简化消息传递 (sMP) 方程

$$m_{i \rightarrow a} = \tanh\left(\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}\right), \quad (11.5a)$$

$$u_{b \rightarrow i} = \tanh^{-1}\left[\tanh(\beta G_{b \rightarrow i}) \tanh\left(\frac{\beta \sigma_i^b}{\sqrt{N}}\right)\right]. \quad (11.5b)$$

若 Bethe 近似自洽，消息收敛后 $P_i(\xi_i) = (1 + m_i \xi_i)/2$ ， $m_i = \tanh(\sum_b u_{b \rightarrow i})$ 。sMP 的时间与存储复杂度仍为 $O(MN)$ ，这促使我们推导近似消息传递 (AMP) 方程 [3, 4]。

对式 (11.5b) 中的 $\beta \sigma_i^b / \sqrt{N}$ 展开，

$$u_{b \rightarrow i} \simeq \frac{\beta \sigma_i^b}{\sqrt{N}} \tanh(\beta G_{b \rightarrow i}). \quad (11.6)$$

另一方面，

$$m_{i \rightarrow a} = \tanh[\tanh^{-1}(m_i) - u_{a \rightarrow i}], \quad (11.7)$$

从而

$$m_{i \rightarrow a} \simeq m_i - (1 - m_i^2) \frac{\beta \sigma_i^a}{\sqrt{N}} \tanh(\beta G_{a \rightarrow i}). \quad (11.8)$$

再写成

$$G_{b \rightarrow i} = G_b - \frac{1}{\sqrt{N}} \sigma_i^b m_{i \rightarrow b}, \quad (11.9)$$

其中

$$G_a = \frac{1}{\sqrt{N}} \sum_{i \in \partial a} \sigma_i^a m_{i \rightarrow a}. \quad (11.10)$$

把式 (11.8) 代入式 (11.10), 得到

$$G_a = \frac{1}{\sqrt{N}} \sum_i \sigma_i^a m_i - \frac{\beta}{N} \sum_i (1 - m_i^2) \tanh(\beta G_{a \rightarrow i}). \quad (11.11)$$

以 $G_{a \rightarrow i} \simeq G_a$ 近似, 并定义 $Q = N^{-1} \sum_i m_i^2$,

$$G_a = \frac{1}{\sqrt{N}} \sum_i \sigma_i^a m_i - \beta(1 - Q) \tanh(\beta G_a). \quad (11.12)$$

定义局域场 $H_i = \sum_b \sigma_i^b \tanh(\beta G_{b \rightarrow i}) / \sqrt{N}$, 对腔修正展开有

$$H_i \simeq \sum_b \frac{\sigma_i^b}{\sqrt{N}} \tanh(\beta G_b) - \frac{\beta m_i}{N} \sum_b [1 - \tanh^2(\beta G_b)], \quad (11.13)$$

以及

$$m_i \simeq \tanh \left\{ \sum_b \frac{\beta \sigma_i^b}{\sqrt{N}} \tanh(\beta G_b) - \frac{\beta^2 m_i}{N} \sum_b [1 - \tanh^2(\beta G_b)] \right\}. \quad (11.14)$$

因此 AMP 闭合方程为

$$G_a = \frac{1}{\sqrt{N}} \sum_i \sigma_i^a m_i - \beta(1 - Q) \tanh(\beta G_a), \quad (11.15a)$$

$$m_i = \tanh \left\{ \sum_b \frac{\beta \sigma_i^b}{\sqrt{N}} \tanh(\beta G_b) - \frac{\beta^2 m_i}{N} \sum_b [1 - \tanh^2(\beta G_b)] \right\}. \quad (11.15b)$$

正确的迭代次序为

$$G_a^{t-1} = \frac{1}{\sqrt{N}} \sum_i \sigma_i^a m_i^{t-1} - \beta(1 - Q^{t-1}) \tanh(\beta G_a^{t-2}), \quad (11.16a)$$

$$m_i^t \simeq \tanh \left\{ \sum_b \frac{\beta \sigma_i^b}{\sqrt{N}} \tanh(\beta G_b^{t-1}) - \frac{\beta^2 m_i^{t-1}}{N} \sum_b [1 - \tanh^2(\beta G_b^{t-1})] \right\}. \quad (11.16b)$$

AMP 中的 Onsager 反作用项与平均场模型的 TAP 方程密切相关, 同时显著降低了 sMP 的存储需求.

11.3 副本计算

副本法计算整数幂 Z^n 的无序平均, 再取 $n \rightarrow 0$, 从而得到

$$-\beta f = \lim_{N \rightarrow \infty} \frac{[\ln Z]}{N} = \lim_{\substack{n \rightarrow 0 \\ N \rightarrow \infty}} \frac{\ln[Z^n]}{nN}. \quad (11.17)$$

11.3.1 $[Z^n]$ 的显式形式

学习后验的配分函数为

$$Z = \sum_{\xi} \prod_a \cosh\left(\frac{\beta}{\sqrt{N}} \xi^T \sigma^a\right), \quad (11.18)$$

故

$$Z^n = \sum_{\{\xi^\gamma\}} \prod_{a,\gamma} \cosh\left(\frac{\beta}{\sqrt{N}} (\xi^\gamma)^T \sigma^a\right). \quad (11.19)$$

令方括号同时表示对真实特征 ξ^* 和由它生成的数据的平均，则

$$[Z^n] = \frac{1}{2^N} \sum_{\{\sigma^a\}, \xi^*} P(\{\sigma^a\} | \xi^*) \sum_{\{\xi^\gamma\}} \prod_{a,\gamma} \cosh\left(\frac{\beta}{\sqrt{N}} (\xi^\gamma)^T \sigma^a\right). \quad (11.20)$$

独立样本的生成概率为

$$\begin{aligned} P(\{\sigma^a\} | \xi^*) &= \prod_a \frac{\cosh[\beta(\xi^*)^T \sigma^a / \sqrt{N}]}{[2 \cosh(\beta/\sqrt{N})]^N} \\ &\simeq \frac{1}{2^{NM}} \prod_a e^{-\beta^2/2} \cosh\left[\frac{\beta}{\sqrt{N}} (\xi^*)^T \sigma^a\right]. \end{aligned} \quad (11.21)$$

于是

$$[Z^n] = \frac{1}{2^N 2^{NM}} \sum_{\{\sigma^a\}, \xi^*, \{\xi^\gamma\}} \prod_a e^{-\beta^2/2} \cosh\left[\frac{\beta}{\sqrt{N}} (\xi^*)^T \sigma^a\right] \prod_{a,\gamma} \cosh\left[\frac{\beta}{\sqrt{N}} (\xi^\gamma)^T \sigma^a\right]. \quad (11.22)$$

11.3.2 副本对称设定下的估计

定义

$$u^a = \frac{(\xi^*)^T \sigma^a}{\sqrt{N}}, \quad v^{a\gamma} = \frac{(\xi^\gamma)^T \sigma^a}{\sqrt{N}}.$$

它们均值为零、方差为一，协方差由序参量

$$q^\gamma = \frac{1}{N} \sum_i \xi_i^\gamma \xi_i^*, \quad r^{\gamma\gamma'} = \frac{1}{N} \sum_i \xi_i^\gamma \xi_i^{\gamma'}$$

给出. 用 delta 函数引入这些定义，

$$\begin{aligned} [Z^n] &= \frac{1}{2^N 2^{NM}} \int \prod_{\gamma} \frac{dq^\gamma d\hat{q}^\gamma}{2\pi} \prod_{\gamma < \gamma'} \frac{dr^{\gamma\gamma'} d\hat{r}^{\gamma\gamma'}}{2\pi} \sum_{\{\sigma^a\}, \xi^*, \{\xi^\gamma\}} \\ &\times \exp\left[-i \sum_{\gamma} \hat{q}^\gamma \left(q^\gamma - \frac{1}{N} \sum_i \xi_i^\gamma \xi_i^*\right) - i \sum_{\gamma < \gamma'} \hat{r}^{\gamma\gamma'} \left(r^{\gamma\gamma'} - \frac{1}{N} \sum_i \xi_i^\gamma \xi_i^{\gamma'}\right)\right] \\ &\times \prod_a e^{-\beta^2/2} \cosh(\beta u^a) \prod_{a,\gamma} \cosh(\beta v^{a\gamma}). \end{aligned} \quad (11.23)$$

在副本对称 (RS) 设定下 $q^\gamma = q$ 、 $r^{\gamma\gamma'} = r$ ，因而

$$-i \sum_{\gamma} \hat{q}^\gamma q^\gamma = -inq\hat{q}, \quad (11.24)$$

$$-i \sum_{\gamma < \gamma'} \hat{r}^{\gamma\gamma'} r^{\gamma\gamma'} = -i \frac{n(n-1)}{2} r\hat{r}. \quad (11.25)$$

把作用量分为熵项 G_S 与能量项 G_E . 对站点求和并作 Hubbard–Stratonovich 变换，熵项为

$$\begin{aligned} (G_S)^N &= \sum_{\xi^*, \{\xi^\gamma\}} \exp \left[\hat{q} \sum_{\gamma i} \xi_i^\gamma \xi_i^* + \frac{\hat{r}}{2} \sum_i \left(\sum_{\gamma} \xi_i^\gamma \right)^2 - \frac{n\hat{r}}{2} N \right] \\ &= 2^N \left[\int Dz e^{-n\hat{r}/2} \{2 \cosh(\hat{q} + \sqrt{\hat{r}} z)\}^n \right]^N. \end{aligned} \quad (11.26)$$

抵消式 (11.23) 的 2^{-N} 后，

$$G_S = \int Dz e^{-n\hat{r}/2} \{2 \cosh(\hat{q} + \sqrt{\hat{r}} z)\}^n. \quad (11.27)$$

为计算能量项，以相互独立的标准 Gaussian 变量 t, x^γ, y 参数化

$$u = t, \quad (11.28)$$

$$v^\gamma = qt + \sqrt{1-r} x^\gamma + \sqrt{r-q^2} y. \quad (11.29)$$

于是

$$G_E^M = \left\{ e^{-\beta^2/2} \int Dt Dy \prod_{\gamma} Dx^\gamma \cosh(\beta t) \prod_{\gamma} \cosh[\beta qt + \beta \sqrt{1-r} x^\gamma + \beta \sqrt{r-q^2} y] \right\}^M. \quad (11.30)$$

用 $\int Dz \cosh(az + c) = e^{a^2/2} \cosh c$,

$$G_E^M = \left\{ e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \left[e^{\beta^2(1-r)/2} \cosh(\beta qt + \beta \sqrt{r-q^2} y) \right]^n \right\}^M, \quad (11.31)$$

故单样本能量项为

$$G_E = e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \left[e^{\beta^2(1-r)/2} \cosh(\beta qt + \beta \sqrt{r-q^2} y) \right]^n. \quad (11.32)$$

汇总得到

$$[Z^n] = \int \frac{dq d\hat{q}}{2\pi i/N} \frac{dr d\hat{r}}{2\pi i/N} \exp \left\{ -Nnq\hat{q} - Nr\hat{r} \frac{n(n-1)}{2} - \frac{Nn\hat{r}}{2} + N \ln G_S + \alpha N \ln G_E \right\}. \quad (11.33)$$

大 N 极限由指数中作用量的鞍点控制.

11.3.3 自由能与鞍点方程

RS 自由能为

$$-\beta f_{\text{RS}} = \lim_{n \rightarrow 0} \left[-q\hat{q} - \frac{n-1}{2}r\hat{r} + \frac{\ln G_S}{n} + \alpha \frac{\ln G_E}{n} \right], \quad (11.34)$$

其中

$$G_S = \int Dz e^{-n\hat{r}/2} \{2 \cosh(\hat{q} + \sqrt{\hat{r}}z)\}^n, \quad (11.35)$$

$$G_E = e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \left[e^{\beta^2(1-r)/2} \cosh(\beta qt + \beta \sqrt{r-q^2}y) \right]^n. \quad (11.36)$$

两个 $n \rightarrow 0$ 极限分别为

$$\lim_{n \rightarrow 0} \frac{\ln G_S}{n} = -\frac{\hat{r}}{2} + \int Dz \ln[2 \cosh(\hat{q} + \sqrt{\hat{r}}z)], \quad (11.37)$$

以及

$$\lim_{n \rightarrow 0} \frac{\ln G_E}{n} = \frac{\beta^2}{2}(1-r) + e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \ln \cosh[\beta(qt + \sqrt{r-q^2}y)]. \quad (11.38)$$

最终

$$\begin{aligned} -\beta f_{\text{RS}} = & -q\hat{q} + \frac{\hat{r}(r-1)}{2} + \frac{\alpha\beta^2}{2}(1-r) + \int Dz \ln[2 \cosh(\hat{q} + \sqrt{\hat{r}}z)] \\ & + \alpha e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \ln \cosh[\beta(qt + \sqrt{r-q^2}y)]. \end{aligned} \quad (11.39)$$

对四个序参量求驻值得

$$\frac{\partial(-\beta f_{\text{RS}})}{\partial \hat{q}} = -q + \int Dz \tanh(\hat{q} + \sqrt{\hat{r}}z), \quad (11.40a)$$

$$\frac{\partial(-\beta f_{\text{RS}})}{\partial \hat{r}} = \frac{r}{2} - \frac{1}{2} \int Dz \tanh^2(\hat{q} + \sqrt{\hat{r}}z), \quad (11.40b)$$

$$\frac{\partial(-\beta f_{\text{RS}})}{\partial q} = -\hat{q} + \alpha\beta^2 e^{-\beta^2/2} \int Dt Dy \sinh(\beta t) \tanh[\beta(qt + \sqrt{r-q^2}y)], \quad (11.40c)$$

$$\frac{\partial(-\beta f_{\text{RS}})}{\partial r} = \frac{\hat{r}}{2} - \frac{\alpha\beta^2}{2} e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \tanh^2[\beta(qt + \sqrt{r-q^2}y)]. \quad (11.40d)$$

故鞍点方程为

$$q = \int Dz \tanh(\hat{q} + \sqrt{\hat{r}}z), \quad (11.41a)$$

$$r = \int Dz \tanh^2(\hat{q} + \sqrt{\hat{r}}z), \quad (11.41b)$$

$$\hat{q} = \alpha\beta^2 e^{-\beta^2/2} \int Dt Dy \sinh(\beta t) \tanh[\beta(qt + \sqrt{r-q^2}y)], \quad (11.41c)$$

$$\hat{r} = \alpha\beta^2 e^{-\beta^2/2} \int Dt Dy \cosh(\beta t) \tanh^2[\beta(qt + \sqrt{r-q^2}y)]. \quad (11.41d)$$

11.4 相变

先从 sMP 方程研究热力学极限. 定义腔场

$$H_{i \rightarrow a} = \frac{1}{\sqrt{N}} \sum_{b \in \partial i \setminus a} \sigma_i^b \tanh(\beta G_{b \rightarrow i}), \quad (11.42)$$

其中

$$G_{b \rightarrow i} = \frac{1}{\sqrt{N}} \sum_{j \in \partial b \setminus i} \sigma_j^b m_{j \rightarrow b}. \quad (11.43)$$

RS 下, 大 N 时 $H_{i \rightarrow a}$ 为均值零的 Gaussian 变量:

$$[H_{i \rightarrow a}] = 0, \quad (11.44a)$$

$$[(H_{i \rightarrow a})^2] = \frac{M}{N} [\tanh^2(\beta G_{b \rightarrow i})] = \alpha \hat{Q}. \quad (11.44b)$$

类似地,

$$[G_{b \rightarrow i}] = 0, \quad (11.45a)$$

$$[(G_{b \rightarrow i})^2] = \frac{1}{N} \sum_j m_{j \rightarrow b}^2 = Q. \quad (11.45b)$$

因此

$$\hat{Q} = \int Dz \tanh^2(\beta \sqrt{Q} z), \quad (11.46a)$$

$$Q = \int Dz \tanh^2(\beta \sqrt{\alpha \hat{Q}} z). \quad (11.46b)$$

$Q = 0$ 是无序或对称解, 消息不含真实特征信息. 当 α 增大到临界点时, 非平凡解连续出现. 令 $Q = O(\epsilon)$, 则 $\hat{Q} \simeq \beta^2 \epsilon$, 从而

$$Q = \int Dz \tanh^2(\beta \sqrt{\alpha \hat{Q}} z) \simeq \beta^2 \alpha \beta^2 \epsilon \int Dz z^2. \quad (11.47)$$

因 $\int Dz z^2 = 1$,

$$Q = \beta^4 \alpha \epsilon. \quad (11.48)$$

恢复迭代指标,

$$\epsilon^{t+1} = \alpha \beta^4 \epsilon^t. \quad (11.49)$$

故 $\alpha \beta^4 < 1$ 时零解稳定, 临界点 $\alpha_c = \beta^{-4}$. 图 11.3 的临界慢化支持这里发生连续相变. 但偏置消息使相变后 Gaussian 场假设失效, sMP 的统计分析不能正确预测相变后的 Q , 需用副本计算.




fig. 11.3 An illustration of critical point α_c . The simulation is made based on three different temperatures: $\beta = 1.2$, $\beta = 1$ and $\beta = 0.9$. The fixed point of Q and convergence time of sMP are

图 11.3: 临界点 α_c 示意图. 模拟采用 $\beta = 1.2, 1, 0.9$; 同时给出 sMP 的 Q 不动点和以迭代步数计的收敛时间 (虚线) .

在最优 Bayesian 推断中, 算法知道真实温度, Nishimori 条件给出 $q = r$, 数值求解式 (11.41) 也验证了这一点. 对小 q, r 展开:

$$\hat{q} = \alpha\beta^4 q, \quad (11.50a)$$

$$\hat{r} = \alpha\beta^4 (q^2\beta^2 + r), \quad (11.50b)$$

$$q = \hat{q} = \alpha\beta^4 q, \quad (11.50c)$$

$$r = \hat{q}^2 + \hat{r} = (\alpha\beta^4 q)^2 + \alpha\beta^4 q^2\beta^2 + \alpha\beta^4 r \simeq \alpha\beta^4 r. \quad (11.50d)$$

q, r 因而给出同一临界点 $\alpha_c = \beta^{-4}$. 其上 $q = 0$ 失稳; 这也是自发对称破缺, 因为模型在 $\xi \rightarrow -\xi$ 下原本对称. 理论与单实例 sMP 数值结果符合良好 (图 11.4) .

11.5 测量数据集温度

触发无监督学习的临界样本数由逆温度 β 决定, 而 β 表征原始输入的噪声. 现在反过来从数据推断生成温度. 在超参数均匀先验 P_0 下,

$$\begin{aligned} P(\beta | \{\sigma^a\}) &= \sum_{\xi} P(\beta, \xi | \{\sigma^a\}) \\ &= \frac{\sum_{\xi} P(\{\sigma^a\} | \xi, \beta) P_0(\xi, \beta)}{\int d\beta \sum_{\xi} P(\{\sigma^a\} | \xi, \beta) P_0(\xi, \beta)}. \end{aligned} \quad (11.51)$$




Fig. 11.4 Order parameters versus α . The theoretical predictions of replica computation are indicated by lines, while the numerical simulations of q on single instances are indicated by symbols

图 11.4: 序参量随 α 的变化. 线为副本计算预测; 符号为单实例 q 的数值模拟, 实心圆对应 $\beta = 1.0$, 实心菱形对应 $\beta = 0.8$.

生成模型满足

$$P(\{\sigma^a\} | \beta, \xi) = \prod_a \frac{\cosh[\beta \xi^\top \sigma^a / \sqrt{N}]}{\sum_{\sigma} \cosh[\beta \xi^\top \sigma / \sqrt{N}]} \quad (11.52)$$

因此

$$P(\beta | \{\sigma^a\}) = \frac{1}{Z(\{\sigma^a\})} \frac{1}{\tilde{Z}^M} \sum_{\xi} \prod_a \cosh\left(\frac{\beta}{\sqrt{N}} \xi^\top \sigma^a\right), \quad \tilde{Z} = [2 \cosh(\beta/\sqrt{N})]^N. \quad (11.53)$$

显式写为

$$P(\beta | \{\sigma^a\}) = \frac{1}{Z(\{\sigma^a\})} e^{-MN \ln[2 \cosh(\beta/\sqrt{N})]} \sum_{\xi} \prod_a \cosh\left(\frac{\beta}{\sqrt{N}} \xi^\top \sigma^a\right). \quad (11.54)$$

大 N 时归一化因子近似为 $e^{-M\beta^2/2}$, 于是

$$P(\beta | \{\sigma^a\}) \propto e^{-M\beta^2/2} \sum_{\xi, a} \cosh\left(\frac{\beta}{\sqrt{N}} \xi^\top \sigma^a\right) \propto e^{-M\beta^2/2} Z(\beta, \{\sigma^a\}). \quad (11.55)$$

最大似然估计 $\hat{\beta} = \arg \max_{\beta} P(\beta | \{\sigma^a\})$ 满足

$$\frac{\partial P(\beta | \{\sigma^a\})}{\partial \beta} = 0, \quad (11.56a)$$

$$\frac{\partial Z(\beta, \{\sigma^a\})}{\partial \beta} = Z M \beta, \quad (11.56b)$$

$$\frac{1}{N} \frac{\partial \ln Z(\beta, \{\sigma^a\})}{\partial \beta} = \frac{M}{N} \beta = \alpha \beta. \quad (11.56c)$$

统计物理中，式 (11.56c) 左边是负能量密度 $-\epsilon$ ，故 $\beta = -\epsilon/\alpha$ ，这是 Nishimori 条件。有限 N 时， $\beta = \sqrt{N} \tanh^{-1}[-\epsilon/(\alpha\sqrt{N})]$ 。

Bethe 近似下，能量满足 $N\epsilon = -\sum_i \epsilon_i + (N-1)\sum_a \epsilon_a$ ，其中

$$\epsilon_i = \frac{\sum_{a \in \partial i} \mathcal{H}_{a \rightarrow i}(+1) + (\prod_{a \in \partial i} \mathcal{G}_{a \rightarrow i}) \sum_{a \in \partial i} \mathcal{H}_{a \rightarrow i}(-1)}{\beta + \beta \prod_{a \in \partial i} \mathcal{G}_{a \rightarrow i}}, \quad (11.57a)$$

$$\epsilon_a = \beta \Xi_a^2 + G_a \tanh(\beta G_a), \quad (11.57b)$$

$\Xi_a^2 = N^{-1} \sum_{i \in \partial a} (1 - m_{i \rightarrow a}^2)$ ，且

$$\mathcal{H}_{a \rightarrow i}(\xi_i) = \beta^2 \Xi_{a \rightarrow i}^2 + \left(\beta G_{a \rightarrow i} + \frac{\beta \sigma_i^a \xi_i}{\sqrt{N}} \right) \tanh \left(\beta G_{a \rightarrow i} + \frac{\beta \sigma_i^a \xi_i}{\sqrt{N}} \right), \quad \mathcal{G}_{a \rightarrow i} = e^{-2u_{a \rightarrow i}}. \quad (11.58)$$

这些量可由自由能的腔近似直接导出。

用期望最大化 (EM) 实现超参数更新 [5]： $\beta(t) = -\epsilon(t)/\alpha$ 。消息更新是 E 步，温度更新是 M 步。从初值 β_0 出发交替更新至收敛；为避免数值不稳定，可采用阻尼 $\beta(t) = \eta \beta(t) + (1 - \eta) \beta(t-1)$ ， $\eta \in [0, 1]$ 。图 11.5 显示，推断温度的偏差随数据量增大而减小。




fig. 11.5 The inference performance of the hyper-parameter β . Deviation of inferred β from the true value decreases with the data size. In simulations, we consider 20 instances of size $N = 100$, and use $\eta = 0.02$ and initial value of $\beta_0 = 0.8$. Two representative trajectories of $\beta(t)$ are shown

图 11.5: 超参数 β 的推断性能. 推断值与真实值的偏差随数据量减小. 模拟取二十个 $N = 100$ 实例, $\eta = 0.02, \beta_0 = 0.8$; 插图给出两条代表性 $\beta(t)$ 轨迹.

参考文献

- [1] H. Huang and T. Toyozumi, Phys. Rev. E **94**, 062310 (2016).
- [2] H. Huang, J. Stat. Mech.: Theory Exper. **2017**(5), 053302 (2017).
- [3] Y. Kabashima, J. Phys. A **36**(43), 11111 (2003).
- [4] D. Donoho, A. Maleki, and A. Montanari, Proc. Natl. Acad. Sci. U.S.A. **106**, 18914 (2009).
- [5] A. P. Dempster, N. M. Laird, and D. B. Rubin, J. R. Stat. Soc. Ser. B **39**, 1 (1977).

无监督学习中的内禀对称破缺

本章研究一个无监督学习玩具模型. 它具有内禀的自旋反演对称性, 以及任意两个隐藏神经元之间的置换对称性; 随着数据量增大, 这些对称性会依次破缺, 从而在最简设定中揭示无监督学习的本质 [1, 2].

12.1 模型设定

采用图 12.1 所示二比特二元 RBM, 以两个隐藏神经元学习输入样本中嵌入的特征. 每个样本为二元构型 $\sigma = \{\sigma_i = \pm 1\}_{i=1}^N$, N 是输入维数, 数据集记作 $\{\sigma^a\}_{a=1}^M$. 连接可见与隐藏神经元的突触也取 ± 1 . 两个隐藏神经元对应的特征 $\xi = (\xi^1, \xi^2)$ 亦称第一、第二隐藏神经元的感受野. 给定两个感受野, 联合分布为

$$P(\sigma, h_1, h_2 | \xi^1, \xi^2) = \frac{1}{Z(\xi^1, \xi^2)} \exp \left[\frac{\beta}{\sqrt{N}} (\xi^1 \cdot \sigma h_1 + \xi^2 \cdot \sigma h_2) \right]. \quad (12.1)$$

其中 h_μ 是隐藏神经元活动, $X = N^{-1/2} \xi^1 \cdot \sigma$, $Y = N^{-1/2} \xi^2 \cdot \sigma$. $N^{-1/2}$ 保证双曲余弦的宗量为 $O(1)$, β 是逆温度.




图 12.1: 二比特 RBM 示意图, 此例 $N = 4$. 左: 仅有两个隐藏神经元 x, y 的原模型. 右: 对应因子图, 方形为数据节点, 圆形为成对突触 (特征向量); 此例 $M = 3$. 圆形变量节点是单比特 RBM 单突触的扩展. 图取自文献 [1].

对两个隐藏态求和, 输入边缘分布为

$$P(\sigma) = \sum_{h_1, h_2} P(\sigma, h_1, h_2 | \xi^1, \xi^2) = \frac{1}{Z(\xi^1, \xi^2)} \cosh(\beta X) \cosh(\beta Y). \quad (12.2)$$

逆温度调节从嵌入特征生成样本时的噪声. 数据分布在交换两个隐藏神经元时不变: $P(\sigma | \xi^1, \xi^2) = P(\sigma | \xi^2, \xi^1)$. 这称为置换对称性; 至少需要两个隐藏神经元, 故本设定是研究无监督学习置换对称性的最小模型.

嵌入特征服从 $P(\boldsymbol{\xi}) = P(\boldsymbol{\xi}^1)P(\boldsymbol{\xi}^2 | \boldsymbol{\xi}^1)$, 其中第一感受野各分量均匀取 ± 1 , 而

$$P(\boldsymbol{\xi}^2 | \boldsymbol{\xi}^1) = \prod_{i=1}^N [p_d \delta(\xi_i^2 = -\xi_i^1) + (1 - p_d) \delta(\xi_i^2 = \xi_i^1)]. \quad (12.3)$$

p_d 指定两个特征图中取不同值的分量比例.

先考虑对 $\boldsymbol{\xi}$ 没有先验知识. 给定 M 个样本, Bayes 规则给出

$$\begin{aligned} P(\boldsymbol{\xi} | \{\boldsymbol{\sigma}^a\}_{a=1}^M) &= \frac{\prod_a P(\boldsymbol{\sigma}^a | \boldsymbol{\xi})}{\sum_{\boldsymbol{\xi}} \prod_a P(\boldsymbol{\sigma}^a | \boldsymbol{\xi})} \\ &= \frac{1}{\Omega} \prod_a \frac{1}{Z(\boldsymbol{\xi}^1, \boldsymbol{\xi}^2)} \cosh\left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^1 \cdot \boldsymbol{\sigma}^a\right) \cosh\left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^2 \cdot \boldsymbol{\sigma}^a\right). \end{aligned} \quad (12.4)$$

推断温度取为生成温度, 但未使用含 p_d 的真实先验, 故这并非满足 Nishimori 条件的 Bayes 最优设定. 嵌套配分函数在大 N 极限可化简:

$$\begin{aligned} Z(\boldsymbol{\xi}^1, \boldsymbol{\xi}^2) &= \sum_{\boldsymbol{\sigma}} \cosh\left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^1 \cdot \boldsymbol{\sigma}\right) \cosh\left(\frac{\beta}{\sqrt{N}} \boldsymbol{\xi}^2 \cdot \boldsymbol{\sigma}\right) \\ &= \frac{1}{2} \prod_i 2 \cosh\left[\frac{\beta}{\sqrt{N}}(\xi_i^1 + \xi_i^2)\right] + \frac{1}{2} \prod_i 2 \cosh\left[\frac{\beta}{\sqrt{N}}(\xi_i^1 - \xi_i^2)\right] \\ &\simeq 2^N e^{\beta^2 Q} \cosh(\beta^2 Q), \quad Q = \frac{1}{N} \sum_i \xi_i^1 \xi_i^2. \end{aligned} \quad (12.5)$$

这里用到小 x 时 $\ln \cosh x \simeq x^2/2$, Q 是两个特征图的重叠. 把无关常数吸收到 Ω 后,

$$P(\boldsymbol{\xi} | \{\boldsymbol{\sigma}^a\}_{a=1}^M) = \frac{1}{\Omega} \prod_a \frac{\cosh(\beta \boldsymbol{\xi}^1 \cdot \boldsymbol{\sigma}^a / \sqrt{N}) \cosh(\beta \boldsymbol{\xi}^2 \cdot \boldsymbol{\sigma}^a / \sqrt{N})}{\cosh^2(\beta^2 Q)}. \quad (12.6)$$

下文关注 $M = \alpha N$, 其中 α 是数据 (约束) 密度.

12.1.1 腔近似

目标是计算最大后验边缘 (MPM) 估计

$$(\hat{\xi}_i^1, \hat{\xi}_i^2) = \arg \max_{\xi_i^1, \xi_i^2} P_i(\xi_i^1, \xi_i^2).$$

样本约束之间的相互作用使边缘概率一般不可处理. 把数据约束与成对突触分别看作因子节点与变量节点, 并假定图上成对突触弱相关, 即 Bethe 近似, 就能通过消息传递计算边缘分布. 定义移除数据节点 a 后的腔概率 $P_{i \rightarrow a}(\xi_i^1, \xi_i^2)$, 有

$$P_{i \rightarrow a}(\xi_i^1, \xi_i^2) = \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2), \quad (12.7a)$$

$$\mu_{b \rightarrow i}(\xi_i^1, \xi_i^2) = \sum_{\boldsymbol{\xi} \setminus (\xi_i^1, \xi_i^2)} \frac{\cosh[\beta X_b + \beta \xi_i^1 \sigma_i^b / \sqrt{N}] \cosh[\beta Y_b + \beta \xi_i^2 \sigma_i^b / \sqrt{N}]}{\cosh^2[\beta^2 Q_c + \beta^2 \xi_i^1 \xi_i^2 / N]} \prod_{j \in \partial b \setminus i} P_{j \rightarrow b}(\xi_j^1, \xi_j^2). \quad (12.7b)$$

其中

$$X_b = \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^1 \sigma_j^b, \quad Y_b = \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^2 \sigma_j^b, \quad Q_c = \frac{1}{N} \sum_{j \neq i} \xi_j^1 \xi_j^2.$$

虽然式 (12.7b) 的求和仍不可处理, 但中心极限定理表明 X_b, Y_b 近似为相关 Gaussian 变量. 所需均值、方差和协方差为

$$G_{b \rightarrow i}^1 = \frac{1}{\sqrt{N}} \sum_{j \neq i} \sigma_j^b m_{j \rightarrow b}^1, \quad (12.8a)$$

$$G_{b \rightarrow i}^2 = \frac{1}{\sqrt{N}} \sum_{j \neq i} \sigma_j^b m_{j \rightarrow b}^2, \quad (12.8b)$$

$$\Gamma_1^{b \rightarrow i} = \frac{1}{N} \sum_{j \neq i} [1 - (m_{j \rightarrow b}^1)^2], \quad (12.8c)$$

$$\Gamma_2^{b \rightarrow i} = \frac{1}{N} \sum_{j \neq i} [1 - (m_{j \rightarrow b}^2)^2], \quad (12.8d)$$

$$\Xi^{b \rightarrow i} = \frac{1}{N} \sum_{j \neq i} [q_{j \rightarrow b} - m_{j \rightarrow b}^1 m_{j \rightarrow b}^2]. \quad (12.8e)$$

因此

$$\begin{aligned} \langle X_b \rangle &= G_{b \rightarrow i}^1, & \langle Y_b \rangle &= G_{b \rightarrow i}^2, \\ \langle X_b^2 \rangle - \langle X_b \rangle^2 &= \Gamma_1^{b \rightarrow i}, & \langle Y_b^2 \rangle - \langle Y_b \rangle^2 &= \Gamma_2^{b \rightarrow i}, \\ \langle X_b Y_b \rangle - \langle X_b \rangle \langle Y_b \rangle &= \Xi^{b \rightarrow i}. \end{aligned} \quad (12.9)$$

通过重参数化技巧, 用两个标准 Gaussian 变量 x, y 写成

$$\begin{aligned} X_b &= G_{b \rightarrow i}^1 + \sqrt{\Gamma_1^{b \rightarrow i}} x, \\ Y_b &= G_{b \rightarrow i}^2 + \sqrt{\Gamma_2^{b \rightarrow i}} (\psi x + \sqrt{1 - \psi^2} y), \quad \psi = \frac{\Xi^{b \rightarrow i}}{\sqrt{\Gamma_1^{b \rightarrow i} \Gamma_2^{b \rightarrow i}}}. \end{aligned} \quad (12.10)$$

计算式 (12.7b) 需要下面的解析积分:

$$\begin{aligned} I &= \int Dx Dy \cosh(Ax + D) \cosh(Bx + Cy + E) \\ &= \frac{1}{2} e^{C^2/2} \left[e^{(A+B)^2/2} \cosh(D + E) + e^{(A-B)^2/2} \cosh(D - E) \right]. \end{aligned} \quad (12.11)$$

腔分布可参数化为

$$P_{j \rightarrow b}(\xi_j^1, \xi_j^2) = \frac{1 + m_{j \rightarrow b}^1 \xi_j^1 + m_{j \rightarrow b}^2 \xi_j^2 + q_{j \rightarrow b} \xi_j^1 \xi_j^2}{4},$$

其中 $m_{j \rightarrow b}^{1,2}$ 是腔磁化强度, $q_{j \rightarrow b}$ 是腔关联. 利用上述相关 Gaussian 参数,

$$\begin{aligned} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2) &= \frac{1}{\cosh^2[\beta^2 Q_{b \rightarrow i} + \beta^2 \xi_i^1 \xi_i^2 / N]} \int Dx Dy \cosh \left[\beta \sqrt{\Gamma_1^{b \rightarrow i}} x + \beta G_{b \rightarrow i}^1 + \frac{\beta \xi_i^1 \sigma_i^b}{\sqrt{N}} \right] \\ &\quad \times \cosh \left[\beta \sqrt{\Gamma_2^{b \rightarrow i}} (\psi x + \sqrt{1 - \psi^2} y) + \beta G_{b \rightarrow i}^2 + \frac{\beta \xi_i^2 \sigma_i^b}{\sqrt{N}} \right], \end{aligned} \quad (12.12)$$

其中 $Q_{b \rightarrow i} = N^{-1} \sum_{j \neq i} q_{j \rightarrow b}$. 积分可由式 (12.11) 精确完成. 令 $u_{b \rightarrow i} = \ln \mu_{b \rightarrow i}$, 得到

$$\begin{aligned} u_{b \rightarrow i}(\xi_i^1, \xi_i^2) &= \frac{\beta^2 \Gamma_2^{b \rightarrow i} (1 - \psi^2)}{2} - 2 \ln \cosh \left(\beta^2 Q_{b \rightarrow i} + \frac{\beta^2 \xi_i^1 \xi_i^2}{N} \right) \\ &\quad + \frac{\beta^2}{2} [\Gamma_1^{b \rightarrow i} + \Gamma_2^{b \rightarrow i} + 2\Xi^{b \rightarrow i}] + \ln \cosh \left[\beta G_{b \rightarrow i}^1 + \beta G_{b \rightarrow i}^2 + \frac{\beta \sigma_i^b (\xi_i^1 + \xi_i^2)}{\sqrt{N}} \right] \\ &\quad + \ln \left\{ 1 + e^{-2\beta^2 \Xi^{b \rightarrow i}} \frac{\cosh[\beta G_{b \rightarrow i}^1 - \beta G_{b \rightarrow i}^2 + \beta \sigma_i^b (\xi_i^1 - \xi_i^2)/\sqrt{N}]}{\cosh[\beta G_{b \rightarrow i}^1 + \beta G_{b \rightarrow i}^2 + \beta \sigma_i^b (\xi_i^1 + \xi_i^2)/\sqrt{N}]} \right\}. \end{aligned} \quad (12.13)$$

为闭合迭代, 记 $\mu_{b \rightarrow i}^{s_1 s_2} = \mu_{b \rightarrow i}(\xi_i^1 = s_1, \xi_i^2 = s_2)$. 腔磁化强度与关联可显式写成

$$m_{i \rightarrow a}^1 = \frac{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} - \prod_{b \neq a} \mu_{b \rightarrow i}^{-+} - \prod_{b \neq a} \mu_{b \rightarrow i}^{--}}{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} + \prod_{b \neq a} \mu_{b \rightarrow i}^{-+} + \prod_{b \neq a} \mu_{b \rightarrow i}^{--}}, \quad (12.14a)$$

$$m_{i \rightarrow a}^2 = \frac{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} - \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} - \prod_{b \neq a} \mu_{b \rightarrow i}^{--}}{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} + \prod_{b \neq a} \mu_{b \rightarrow i}^{-+} + \prod_{b \neq a} \mu_{b \rightarrow i}^{--}}, \quad (12.14b)$$

$$q_{i \rightarrow a} = \frac{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{--} - \prod_{b \neq a} \mu_{b \rightarrow i}^{-+} - \prod_{b \neq a} \mu_{b \rightarrow i}^{+-}}{\prod_{b \neq a} \mu_{b \rightarrow i}^{++} + \prod_{b \neq a} \mu_{b \rightarrow i}^{+-} + \prod_{b \neq a} \mu_{b \rightarrow i}^{-+} + \prod_{b \neq a} \mu_{b \rightarrow i}^{--}}. \quad (12.14c)$$

用 $u = \ln \mu$ 可更紧凑地写为

$$m_{i \rightarrow a}^1 = \frac{\sum_{\xi^1, \xi^2} \xi^1 \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}{\sum_{\xi^1, \xi^2} \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}, \quad (12.15a)$$

$$m_{i \rightarrow a}^2 = \frac{\sum_{\xi^1, \xi^2} \xi^2 \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}{\sum_{\xi^1, \xi^2} \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}, \quad (12.15b)$$

$$q_{i \rightarrow a} = \frac{\sum_{\xi^1, \xi^2} \xi^1 \xi^2 \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}{\sum_{\xi^1, \xi^2} \exp[\sum_{b \in \partial i \setminus a} u_{b \rightarrow i}(\xi^1, \xi^2)]}. \quad (12.15c)$$

$m_{i \rightarrow a}^{1,2}$ 与 $q_{i \rightarrow a}$ 是特征节点到数据节点的消息, $u_{b \rightarrow i}$ 是反向消息.

若弱关联设定自洽, 从随机初始消息出发, 方程收敛到 Bethe 自由能的热力学主导极小值:

$$-\beta f_{\text{Bethe}} = \frac{1}{N} \sum_i f_i - \frac{N-1}{N} \sum_a f_a, \quad f_i = \ln Z_i, \quad f_a = \ln Z_a.$$

变量节点和数据节点的自由能贡献为

$$\begin{aligned} Z_i &= \sum_{\xi_i^1, \xi_i^2} \prod_{b \in \partial i} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2), \\ Z_a &= \sum_{\xi^1, \xi^2} \frac{\cosh(\beta \boldsymbol{\xi}^1 \cdot \boldsymbol{\sigma}^a / \sqrt{N}) \cosh(\beta \boldsymbol{\xi}^2 \cdot \boldsymbol{\sigma}^a / \sqrt{N})}{\cosh^2(\beta^2 Q_a)} \prod_{j \in \partial a} P_{j \rightarrow a}(\xi_j^1, \xi_j^2). \end{aligned} \quad (12.16)$$

其中 $Q_a = N^{-1} \sum_j q_{j \rightarrow a}$. 定义相应完整量

$$\begin{aligned} G_a^1 &= \frac{1}{\sqrt{N}} \sum_j \sigma_j^a m_{j \rightarrow a}^1, & G_a^2 &= \frac{1}{\sqrt{N}} \sum_j \sigma_j^a m_{j \rightarrow a}^2, \\ \Gamma_1^a &= \frac{1}{N} \sum_j [1 - (m_{j \rightarrow a}^1)^2], & \Gamma_2^a &= \frac{1}{N} \sum_j [1 - (m_{j \rightarrow a}^2)^2], \\ \Xi^a &= \frac{1}{N} \sum_j (q_{j \rightarrow a} - m_{j \rightarrow a}^1 m_{j \rightarrow a}^2). \end{aligned} \quad (12.17)$$

于是

$$\begin{aligned} X_a &= G_a^1 + \sqrt{\Gamma_1^a} x, \\ Y_a &= G_a^2 + \sqrt{\Gamma_2^a} (\tilde{\psi} x + \sqrt{1 - \tilde{\psi}^2} y), \quad \tilde{\psi} = \frac{\Xi^a}{\sqrt{\Gamma_1^a \Gamma_2^a}}. \end{aligned} \quad (12.18)$$

完成 Gaussian 积分可得

$$\begin{aligned} f_a &= \frac{\beta^2 \Gamma_2^a (1 - \tilde{\psi}^2)}{2} - 2 \ln \cosh(\beta^2 Q_a) + \frac{\beta^2}{2} (\Gamma_1^a + \Gamma_2^a + 2\Xi^a) + \ln \cosh[\beta(G_a^1 + G_a^2)] \\ &\quad + \ln \left[1 + e^{-2\beta^2 \Xi^a} \frac{\cosh[\beta(G_a^1 - G_a^2)]}{\cosh[\beta(G_a^1 + G_a^2)]} \right]. \end{aligned} \quad (12.19)$$

完整边缘概率为

$$P_i(\xi_i^1, \xi_i^2) = \frac{1}{Z_i} \prod_{b \in \partial i} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2) = \frac{1 + m_i^1 \xi_i^1 + m_i^2 \xi_i^2 + q_i \xi_i^1 \xi_i^2}{4}. \quad (12.20)$$

相应矩为

$$m_i^1 = \frac{\sum_{\xi^1, \xi^2} \xi^1 e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}{\sum_{\xi^1, \xi^2} e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}, \quad (12.21a)$$

$$m_i^2 = \frac{\sum_{\xi^1, \xi^2} \xi^2 e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}{\sum_{\xi^1, \xi^2} e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}, \quad (12.21b)$$

$$q_i = \frac{\sum_{\xi^1, \xi^2} \xi^1 \xi^2 e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}{\sum_{\xi^1, \xi^2} e^{\sum_b u_{b \rightarrow i}(\xi^1, \xi^2)}}. \quad (12.21c)$$

若使用因子化先验 $P_0(\xi_i^1, \xi_i^2)$, 后验改为

$$P(\boldsymbol{\xi}^1, \boldsymbol{\xi}^2 | \{\boldsymbol{\sigma}^a\}) = \frac{1}{\Omega} \prod_a \frac{\cosh(\beta \boldsymbol{\xi}^1 \cdot \boldsymbol{\sigma}^a / \sqrt{N}) \cosh(\beta \boldsymbol{\xi}^2 \cdot \boldsymbol{\sigma}^a / \sqrt{N})}{\cosh^2(\beta^2 Q)} \prod_{i=1}^N P_0(\xi_i^1, \xi_i^2). \quad (12.22)$$

BP 方程成为

$$P_{i \rightarrow a}(\xi_i^1, \xi_i^2) = \frac{1}{Z_{i \rightarrow a}} P_0(\xi_i^1, \xi_i^2) \prod_{b \in \partial i \setminus a} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2), \quad (12.23a)$$

$$\mu_{b \rightarrow i}(\xi_i^1, \xi_i^2) = \sum_{\boldsymbol{\xi} \setminus (\xi_i^1, \xi_i^2)} \frac{\cosh[\beta X_b + \beta \xi_i^1 \sigma_i^b / \sqrt{N}] \cosh[\beta Y_b + \beta \xi_i^2 \sigma_i^b / \sqrt{N}]}{\cosh^2[\beta^2 Q_c + \beta^2 \xi_i^1 \xi_i^2 / N]} \prod_{j \neq i} P_{j \rightarrow b}(\xi_j^1, \xi_j^2). \quad (12.23b)$$

腔矩统一为

$$\{m_{i \rightarrow a}^1, m_{i \rightarrow a}^2, q_{i \rightarrow a}\} = \frac{\sum_{\xi^1, \xi^2} \{\xi^1, \xi^2, \xi^1 \xi^2\} e^{\sum_{b \neq a} u_{b \rightarrow i}(\xi^1, \xi^2)} P_0(\xi^1, \xi^2)}{\sum_{\xi^1, \xi^2} e^{\sum_{b \neq a} u_{b \rightarrow i}(\xi^1, \xi^2)} P_0(\xi^1, \xi^2)}. \quad (12.24)$$

自由能位移为

$$f_i = \ln \sum_{\xi_i^1, \xi_i^2} P_0(\xi_i^1, \xi_i^2) \prod_{b \in \partial i} \mu_{b \rightarrow i}(\xi_i^1, \xi_i^2), \quad (12.25a)$$

$$f_a = \frac{\beta^2 \Gamma_2^a (1 - \tilde{\psi}^2)}{2} - 2 \ln \cosh(\beta^2 Q_a) + \frac{\beta^2}{2} (\Gamma_1^a + \Gamma_2^a + 2\Xi^a) + \ln \cosh[\beta(G_a^1 + G_a^2)] \\ + \ln \left[1 + e^{-2\beta^2 \Xi^a} \frac{\cosh[\beta(G_a^1 - G_a^2)]}{\cosh[\beta(G_a^1 + G_a^2)]} \right]. \quad (12.25b)$$

这些含先验或不含先验的 BP 方程都是实际可用的无监督学习算法. 教师-学生实验中, 教师仅以指定的 (ξ^1, ξ^2) 生成无标签数据; 学生在只知道温度, 或同时知道温度与相关先验时, 用上述 BP 推断数据背后的特征.

12.1.2 副本计算

二比特 RBM 的配分函数为

$$\Omega = \sum_{\{\xi^1, \xi^2\}} \prod_{a=1}^M \frac{\cosh(\beta \xi^1 \cdot \sigma^a / \sqrt{N}) \cosh(\beta \xi^2 \cdot \sigma^a / \sqrt{N})}{2^N e^{\beta^2} \cosh(\beta^2 Q)}. \quad (12.26)$$

为解析研究典型性能和自发对称破缺 (SSB) 的临界点, 需要用副本法计算热力学极限自由能. 令 n 为副本数, 方括号表示对所有样本和真实特征实现的无序平均. 由副本技巧,

$$\beta f = \lim_{n \rightarrow 0} \lim_{N \rightarrow \infty} \frac{\ln[\Omega^n]}{nN}. \quad (12.27)$$

给定两个真实特征, 数据分布为

$$P(\{\sigma^a\}) = \prod_{a=1}^M \frac{\cosh(\beta \xi^{1, \text{true}} \cdot \sigma^a / \sqrt{N}) \cosh(\beta \xi^{2, \text{true}} \cdot \sigma^a / \sqrt{N})}{Z(\xi^{1, \text{true}}, \xi^{2, \text{true}})}. \quad (12.28)$$

嵌套配分函数为

$$Z(\xi^{1, \text{true}}, \xi^{2, \text{true}}) = \sum_{\sigma} \cosh(\beta \xi^{1, \text{true}} \cdot \sigma / \sqrt{N}) \cosh(\beta \xi^{2, \text{true}} \cdot \sigma / \sqrt{N}) \\ = 2^N e^{\beta^2} \cosh(\beta^2 q), \quad (12.29)$$

其中 $q = N^{-1} \xi^{1, \text{true}} \cdot \xi^{2, \text{true}}$. 故

$$[\Omega^n] = \sum_{\xi^{\text{true}}, \{\sigma^a\}} \prod_i P(\xi_i^{1, \text{true}}, \xi_i^{2, \text{true}}) \prod_a \frac{\cosh(\beta X_a^0) \cosh(\beta Y_a^0)}{2^N e^{\beta^2} \cosh(\beta^2 q)} \\ \times \sum_{\{\xi^{1, \gamma}, \xi^{2, \gamma}\}} \prod_{a, \gamma} \frac{\cosh(\beta X_a^\gamma) \cosh(\beta Y_a^\gamma)}{\cosh(\beta^2 R^\gamma)}, \quad (12.30)$$

其中 $X_a^\gamma = N^{-1/2} \xi^{1,\gamma} \cdot \sigma^a$, $Y_a^\gamma = N^{-1/2} \xi^{2,\gamma} \cdot \sigma^a$, $R^\gamma = N^{-1} \xi^{1,\gamma} \cdot \xi^{2,\gamma}$.

引入完整的一组序参量:

$$T_1^\gamma = \frac{1}{N} \xi^{1,\text{true}} \cdot \xi^{1,\gamma}, \quad T_2^\gamma = \frac{1}{N} \xi^{2,\text{true}} \cdot \xi^{2,\gamma}, \quad (12.31a)$$

$$\tau_1^\gamma = \frac{1}{N} \xi^{1,\text{true}} \cdot \xi^{2,\gamma}, \quad \tau_2^\gamma = \frac{1}{N} \xi^{2,\text{true}} \cdot \xi^{1,\gamma}, \quad (12.31b)$$

$$q_1^{\gamma\gamma'} = \frac{1}{N} \xi^{1,\gamma} \cdot \xi^{1,\gamma'}, \quad q_2^{\gamma\gamma'} = \frac{1}{N} \xi^{2,\gamma} \cdot \xi^{2,\gamma'}, \quad (12.31c)$$

$$R^\gamma = \frac{1}{N} \xi^{1,\gamma} \cdot \xi^{2,\gamma}, \quad r^{\gamma\gamma'} = \frac{1}{N} \xi^{1,\gamma} \cdot \xi^{2,\gamma'}. \quad (12.31d)$$

$T_{1,2}$ 衡量预测与真实特征的重叠, $q_{1,2}$ 是 Edwards–Anderson 自重叠, $\tau_{1,2}$ 是置换型重叠, 而 R, r 表示学生对植入感受野相关程度的估计.

用 delta 函数逐一施加式 (12.31) 的定义, 副本矩可写成

$$\begin{aligned} [\Omega^n] = & \sum_{\xi^{\text{true}}, \{\sigma^a\}} \prod_i P(\xi_i^{1,\text{true}}, \xi_i^{2,\text{true}}) \sum_{\{\xi^{1,\gamma}, \xi^{2,\gamma}\}} \int \mathcal{D}\mathcal{O} \prod_\gamma \delta(NR^\gamma - \xi^{1,\gamma} \cdot \xi^{2,\gamma}) \\ & \times \prod_{\gamma,k} \delta(NT_k^\gamma - \xi^{k,\text{true}} \cdot \xi^{k,\gamma}) \prod_\gamma \delta(N\tau_1^\gamma - \xi^{1,\text{true}} \cdot \xi^{2,\gamma}) \delta(N\tau_2^\gamma - \xi^{2,\text{true}} \cdot \xi^{1,\gamma}) \\ & \times \prod_{\gamma < \gamma', k} \delta(Nq_k^{\gamma\gamma'} - \xi^{k,\gamma} \cdot \xi^{k,\gamma'}) \prod_{\gamma < \gamma'} \delta(Nr^{\gamma\gamma'} - \xi^{1,\gamma} \cdot \xi^{2,\gamma'}) \mathcal{W}(\sigma, \xi). \end{aligned} \quad (12.32)$$

这里 $\mathcal{W}$ 就是式 (12.30) 中生成分布与所有副本 Boltzmann 因子的乘积; 用 $\delta(x) = \int d\hat{x} e^{i\hat{x}x}/(2\pi)$ 表示每个 delta 函数后, 需要引入共轭序参量

$$(\widehat{T}_1^\gamma, \widehat{T}_2^\gamma, \widehat{\tau}_1^\gamma, \widehat{\tau}_2^\gamma, \widehat{q}_1^{\gamma\gamma'}, \widehat{q}_2^{\gamma\gamma'}, \widehat{R}^\gamma, \widehat{r}^{\gamma\gamma'}). \quad (12.33)$$

它们分别对应物理序参量

$$(T_1^\gamma, T_2^\gamma, \tau_1^\gamma, \tau_2^\gamma, q_1^{\gamma\gamma'}, q_2^{\gamma\gamma'}, R^\gamma, r^{\gamma\gamma'}). \quad (12.34)$$

在副本对称 (RS) 设定下, 对任意 γ ,

$$R^\gamma = R, \quad i\widehat{R}^\gamma = \widehat{R}, \quad (12.35a)$$

$$T_1^\gamma = T_1, \quad i\widehat{T}_1^\gamma = \widehat{T}_1, \quad (12.35b)$$

$$T_2^\gamma = T_2, \quad i\widehat{T}_2^\gamma = \widehat{T}_2, \quad (12.35c)$$

$$\tau_1^\gamma = \tau_1, \quad i\widehat{\tau}_1^\gamma = \widehat{\tau}_1, \quad (12.35d)$$

$$\tau_2^\gamma = \tau_2, \quad i\widehat{\tau}_2^\gamma = \widehat{\tau}_2. \quad (12.35e)$$

对任意 $\gamma \neq \gamma'$,

$$q_1^{\gamma\gamma'} = q_1, \quad i\widehat{q}_1^{\gamma\gamma'} = \widehat{q}_1, \quad (12.36a)$$

$$q_2^{\gamma\gamma'} = q_2, \quad i\widehat{q}_2^{\gamma\gamma'} = \widehat{q}_2, \quad (12.36b)$$

$$r^{\gamma\gamma'} = r, \quad i\widehat{r}^{\gamma\gamma'} = \widehat{r}. \quad (12.36c)$$

于是

$$[\Omega^n] = \int dO d\hat{O} \exp\{NA(O, \hat{O}, \alpha, \beta, n)\}. \quad (12.37)$$

热力学极限由作用量最大值的鞍点控制，且

$$\begin{aligned} A = & -nR\hat{R} - nT_1\hat{T}_1 - nT_2\hat{T}_2 - n\tau_1\hat{\tau}_1 - n\tau_2\hat{\tau}_2 \\ & - \frac{n(n-1)}{2}(q_1\hat{q}_1 + q_2\hat{q}_2 + r\hat{r}) + G_S + \alpha G_E. \end{aligned} \quad (12.38)$$

G_S 与 G_E 分别是熵项和能量项. 推导熵项所用的恒等式为

$$\sum_{\gamma < \gamma'} \xi^{1,\gamma} \xi^{1,\gamma'} = \frac{1}{2} \left(\sum_{\gamma} \xi^{1,\gamma} \right)^2 - \frac{1}{2} \sum_{\gamma} (\xi^{1,\gamma})^2, \quad (12.39a)$$

$$\sum_{\gamma < \gamma'} \xi^{2,\gamma} \xi^{2,\gamma'} = \frac{1}{2} \left(\sum_{\gamma} \xi^{2,\gamma} \right)^2 - \frac{1}{2} \sum_{\gamma} (\xi^{2,\gamma})^2, \quad (12.39b)$$

$$\sum_{\gamma < \gamma'} \xi^{1,\gamma} \xi^{2,\gamma'} = \frac{1}{4} \left(\sum_{\gamma} \xi^{1,\gamma} + \sum_{\gamma} \xi^{2,\gamma} \right)^2 - \frac{1}{4} \left(\sum_{\gamma} \xi^{1,\gamma} \right)^2 - \frac{1}{4} \left(\sum_{\gamma} \xi^{2,\gamma} \right)^2 - \frac{1}{2} \sum_{\gamma} \xi^{1,\gamma} \xi^{2,\gamma}. \quad (12.39c)$$

随后用 Hubbard–Stratonovich 变换把这些二次项线性化.

线性化后，熵项可写为

$$G_S = \ln \left[\sum_{\{\xi^{1,\gamma}, \xi^{2,\gamma}\}} \int Dz_1 Dz_2 Dz_3 \exp \sum_{\gamma} (b_1 \xi^{1,\gamma} + b_2 \xi^{2,\gamma} + b_3 \xi^{1,\gamma} \xi^{2,\gamma}) \right]_{\xi^{1,\text{true}}, \xi^{2,\text{true}}} - \frac{n}{2} (\hat{q}_1 + \hat{q}_2). \quad (12.40)$$

副本求和因而分解，得到紧凑形式

$$G_S = \ln \left[\int D\mathbf{z} \left(\sum_{\xi^1, \xi^2} e^{b_1 \xi^1 + b_2 \xi^2 + b_3 \xi^1 \xi^2} \right)^n \right]_{\xi^{1,\text{true}}, \xi^{2,\text{true}}} - \frac{n}{2} (\hat{q}_1 + \hat{q}_2), \quad (12.41)$$

其中 $D\mathbf{z} = Dz_1 Dz_2 Dz_3$ ，并定义

$$b_1 = \sqrt{\hat{q}_1 - \hat{r}/2} z_1 + \sqrt{\hat{r}/2} z_3 + \hat{T}_1 \xi^{1,\text{true}} + \hat{\tau}_2 \xi^{2,\text{true}}, \quad (12.42a)$$

$$b_2 = \sqrt{\hat{q}_2 - \hat{r}/2} z_2 + \sqrt{\hat{r}/2} z_3 + \hat{T}_2 \xi^{2,\text{true}} + \hat{\tau}_1 \xi^{1,\text{true}}, \quad (12.42b)$$

$$b_3 = \hat{R} - \frac{\hat{r}}{2}. \quad (12.42c)$$

括号内是有效二自旋配分函数

$$Z_{\text{eff}} = \sum_{\xi^1, \xi^2} e^{b_1 \xi^1 + b_2 \xi^2 + b_3 \xi^1 \xi^2} = 2e^{b_3} \cosh(b_1 + b_2) + 2e^{-b_3} \cosh(b_1 - b_2).$$

副本把原自旋相互作用解耦为由重叠矩阵控制的有效二自旋问题.

能量项为

$$G_E = \ln \left[\frac{\cosh(\beta X^0) \cosh(\beta Y^0)}{\cosh(\beta^2 q)} \prod_{\gamma=1}^n \frac{\cosh(\beta X^\gamma) \cosh(\beta Y^\gamma)}{\cosh(\beta^2 R^\gamma)} \right]. \quad (12.43)$$

$X^0, Y^0, X^\gamma, Y^\gamma$ 是均值零、方差一的相关 Gaussian 变量, 其协方差为

$$\langle X^0 Y^0 \rangle = q, \quad \langle X^0 X^\gamma \rangle = T_1, \quad \langle X^0 Y^\gamma \rangle = \tau_1, \quad (12.44a)$$

$$\langle X^\gamma X^{\gamma'} \rangle = q_1, \quad \langle Y^\gamma Y^{\gamma'} \rangle = q_2, \quad \langle X^\gamma Y^\gamma \rangle = R, \quad (12.44b)$$

$$\langle Y^0 Y^\gamma \rangle = T_2, \quad \langle Y^0 X^\gamma \rangle = \tau_2, \quad \langle X^\gamma Y^{\gamma'} \rangle = r \quad (\gamma \neq \gamma'). \quad (12.44c)$$

用独立标准 Gaussian 变量 $(t_0, x_0, u, u', y_\gamma, \omega_\gamma)$ 参数化为

$$X^0 = t_0, \quad (12.45a)$$

$$Y^0 = q t_0 + \sqrt{1 - q^2} x_0, \quad (12.45b)$$

$$X^\gamma = T_1 t_0 + \frac{\tau_2 - T_1 q}{\sqrt{1 - q^2}} x_0 + B u + \sqrt{1 - q_1} \omega_\gamma, \quad (12.45c)$$

$$Y^\gamma = \tau_1 t_0 + \frac{T_2 - \tau_1 q}{\sqrt{1 - q^2}} x_0 + \frac{r - A}{B} u + \frac{R - r}{\sqrt{1 - q_1}} \omega_\gamma + K u' + C y_\gamma. \quad (12.45d)$$

这里

$$A = T_1 \tau_1 + \frac{(\tau_2 - T_1 q)(T_2 - \tau_1 q)}{1 - q^2}, \quad B^2 = q_1 - T_1^2 - \frac{(\tau_2 - T_1 q)^2}{1 - q^2},$$

$$K^2 = q_2 - \tau_1^2 - \frac{(T_2 - \tau_1 q)^2}{1 - q^2} - \left(\frac{r - A}{B} \right)^2, \quad C^2 = 1 - q_2 - \frac{(R - r)^2}{1 - q_1}.$$

此参数化逐项再现式 (12.44). 因而

$$G_E = \ln \int D t_0 D x_0 D u D u' \frac{\cosh(\beta t_0) \cosh[\beta(q t_0 + \sqrt{1 - q^2} x_0)]}{\cosh(\beta^2 q)} \times \left\{ \frac{1}{\cosh(\beta^2 R)} \int D \omega D y \cosh(\beta X) \cosh(\beta Y) \right\}^n. \quad (12.46)$$

为简化表示, 定义

$$\Theta_+ = (T_1 + \tau_1) t_0 + \frac{(T_2 + \tau_2) - q(T_1 + \tau_1)}{\sqrt{1 - q^2}} x_0 + \left(B + \frac{r - A}{B} \right) u + K u', \quad (12.47a)$$

$$\Theta_- = (T_1 - \tau_1) t_0 + \frac{(\tau_2 - T_2) - q(T_1 - \tau_1)}{\sqrt{1 - q^2}} x_0 + \left(B - \frac{r - A}{B} \right) u - K u'. \quad (12.47b)$$

内层积分为

$$I = \int D \omega D y \cosh(\beta X) \cosh(\beta Y) = \frac{1}{2} e^{\beta^2(1 - q_1 + q_2)/2} \left[e^{\beta^2(R - r)} \cosh(\beta \Theta_+) + e^{-\beta^2(R - r)} \cosh(\beta \Theta_-) \right]. \quad (12.48)$$

再定义

$$\begin{aligned}
Z_E &= e^{\beta^2(R-r)} \cosh(\beta\Theta_+) + e^{-\beta^2(R-r)} \cosh(\beta\Theta_-), \\
G_c^- &= \frac{e^{\beta^2(R-r)} \cosh(\beta\Theta_+) - e^{-\beta^2(R-r)} \cosh(\beta\Theta_-)}{Z_E}, \\
G_s^+ &= \frac{e^{\beta^2(R-r)} \sinh(\beta\Theta_+) + e^{-\beta^2(R-r)} \sinh(\beta\Theta_-)}{Z_E}, \quad G_s^- = \frac{e^{\beta^2(R-r)} \sinh(\beta\Theta_+) - e^{-\beta^2(R-r)} \sinh(\beta\Theta_-)}{Z_E}.
\end{aligned} \tag{12.49}$$

取 $n \rightarrow 0$,

$$\lim_{n \rightarrow 0} \frac{G_E}{n} = \frac{\int Dt_0 Dx_0 Du Du' \frac{\cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)]}{\cosh(\beta^2 q)} \ln[I / \cosh(\beta^2 R)]}{\int Dt_0 Dx_0 Du Du' \frac{\cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)]}{\cosh(\beta^2 q)}}. \tag{12.50}$$

分母可精确计算：

$$\int Dt_0 Dx_0 Du Du' \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] = e^{\beta^2} \cosh(\beta^2 q). \tag{12.51}$$

于是副本矩的鞍点表示为

$$\begin{aligned}
[\Omega^n] &= \int dO d\hat{O} \exp \left\{ N \left[-nR\hat{R} - nT_1\hat{T}_1 - nT_2\hat{T}_2 - n\tau_1\hat{\tau}_1 - n\tau_2\hat{\tau}_2 \right. \right. \\
&\quad \left. \left. - \frac{n(n-1)}{2}(q_1\hat{q}_1 + q_2\hat{q}_2 + r\hat{r}) - \frac{n}{2}(\hat{q}_1 + \hat{q}_2) + \ln \int D\mathbf{z} Z_{\text{eff}}^n + \alpha G_E \right] \right\}.
\end{aligned} \tag{12.52}$$

汇总各项，RS 自由能 $F_\beta = -\beta f_{\text{RS}}$ 为

$$\begin{aligned}
F_\beta &= -R\hat{R} - T_1\hat{T}_1 - T_2\hat{T}_2 - \tau_1\hat{\tau}_1 - \tau_2\hat{\tau}_2 + \frac{\hat{q}_1}{2}(q_1 - 1) + \frac{\hat{q}_2}{2}(q_2 - 1) + \frac{r\hat{r}}{2} \\
&\quad + \int D\mathbf{z} [\ln Z_{\text{eff}}]_{\xi^{1,\text{true}}, \xi^{2,\text{true}}} - \alpha \ln[2 \cosh(\beta^2 R)] + \alpha \beta^2 \left(1 - \frac{q_1 + q_2}{2} \right) \\
&\quad + \frac{\alpha e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt_0 Dx_0 Du Du' \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \ln Z_E.
\end{aligned} \tag{12.53}$$

物理序参量满足

$$\partial_R F_\beta = \partial_r F_\beta = \partial_{q_1} F_\beta = \partial_{q_2} F_\beta = 0, \tag{12.54a}$$

$$\partial_{T_1} F_\beta = \partial_{T_2} F_\beta = \partial_{\tau_1} F_\beta = \partial_{\tau_2} F_\beta = 0. \tag{12.54b}$$

共轭序参量满足

$$\partial_{\hat{R}} F_\beta = \partial_{\hat{r}} F_\beta = \partial_{\hat{q}_1} F_\beta = \partial_{\hat{q}_2} F_\beta = 0, \tag{12.55a}$$

$$\partial_{\hat{T}_1} F_\beta = \partial_{\hat{T}_2} F_\beta = \partial_{\hat{\tau}_1} F_\beta = \partial_{\hat{\tau}_2} F_\beta = 0. \tag{12.55b}$$

先求非共轭序参量的自洽方程. 对 R ,

$$\frac{\partial F_\beta}{\partial \widehat{R}} = -R + \int D\mathbf{z} \frac{\partial \ln Z_{\text{eff}}}{\partial \widehat{R}} = 0, \quad (12.56)$$

故

$$R = [\langle \xi^1 \xi^2 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}. \quad (12.57)$$

内层热平均取自有效二自旋模型, 外层再对 Gaussian 变量和真实特征分布平均. 类似地,

$$\frac{\partial F_\beta}{\partial \widehat{T}_1} = -T_1 + \int D\mathbf{z} \frac{1}{Z_{\text{eff}}} \frac{\partial Z_{\text{eff}}}{\partial \widehat{T}_1} = 0, \quad (12.58)$$

从而

$$T_1 = [\xi^{1, \text{true}} \langle \xi^1 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}, \quad (12.59)$$

$$T_2 = [\xi^{2, \text{true}} \langle \xi^2 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}, \quad (12.60)$$

$$\tau_1 = [\xi^{1, \text{true}} \langle \xi^2 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}, \quad (12.61)$$

$$\tau_2 = [\xi^{2, \text{true}} \langle \xi^1 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}. \quad (12.62)$$

对 q_1 , 驻点条件为

$$\frac{\partial F_\beta}{\partial \widehat{q}_1} = \frac{q_1 - 1}{2} + \int D\mathbf{z} \frac{1}{Z_{\text{eff}}} \frac{\partial Z_{\text{eff}}}{\partial \widehat{q}_1} = 0. \quad (12.63)$$

由 b_1 对 $\widehat{q}_1$ 的依赖,

$$q_1 - 1 + \sqrt{\widehat{q}_1 - \widehat{r}/2}^{-1} [\langle \xi^1 \rangle_z z_1]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}} = 0. \quad (12.64)$$

使用 Gaussian 分部积分恒等式

$$\int D\mathbf{z} f(\mathbf{z}) \mathbf{z} = \int D\mathbf{z} f'(\mathbf{z}), \quad (12.65)$$

得到

$$[\langle \xi^1 \rangle_z z_1]_z = \sqrt{\widehat{q}_1 - \widehat{r}/2} [1 - \langle \xi^1 \rangle_z^2]_z. \quad (12.66)$$

于是

$$q_1 = [\langle \xi^1 \rangle_z^2]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}, \quad (12.67)$$

$$q_2 = [\langle \xi^2 \rangle_z^2]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}. \quad (12.68)$$

对 $\widehat{r}$,

$$\frac{r}{2} + \int D\mathbf{z} \left[\frac{\partial \ln Z_{\text{eff}}}{\partial \widehat{r}} \right]_{\xi^{1, \text{true}}, \xi^{2, \text{true}}} = 0. \quad (12.69)$$

其导数显式为

$$\begin{aligned} \frac{\partial \ln Z_{\text{eff}}}{\partial \hat{r}} = & -\frac{\langle \xi^1 \rangle z_1}{4\sqrt{\hat{q}_1 - \hat{r}/2}} + \frac{\langle \xi^1 \rangle z_3}{4\sqrt{\hat{r}/2}} - \frac{\langle \xi^2 \rangle z_2}{4\sqrt{\hat{q}_2 - \hat{r}/2}} \\ & + \frac{\langle \xi^2 \rangle z_3}{4\sqrt{\hat{r}/2}} - \frac{1}{2} \langle \xi^1 \xi^2 \rangle. \end{aligned} \quad (12.70)$$

除式 (12.66) 外, 分部积分还给出

$$\begin{aligned} [\langle \xi^2 \rangle z_2]_z &= \sqrt{\hat{q}_2 - \hat{r}/2} [1 - \langle \xi^2 \rangle_z^2], \\ [\langle \xi^1 \rangle z_3]_z &= \sqrt{\hat{r}/2} [1 - \langle \xi^1 \rangle_z^2 + \langle \xi^1 \xi^2 \rangle_z - \langle \xi^1 \rangle_z \langle \xi^2 \rangle_z], \\ [\langle \xi^2 \rangle z_3]_z &= \sqrt{\hat{r}/2} [1 - \langle \xi^2 \rangle_z^2 + \langle \xi^1 \xi^2 \rangle_z - \langle \xi^1 \rangle_z \langle \xi^2 \rangle_z]. \end{aligned} \quad (12.71)$$

合并得到

$$r = [\langle \xi^1 \rangle_z \langle \xi^2 \rangle_z]_{z, \xi^{1, \text{true}}, \xi^{2, \text{true}}}. \quad (12.72)$$

由 $Z_{\text{eff}} = 2e^{b_3} \cosh(b_1 + b_2) + 2e^{-b_3} \cosh(b_1 - b_2)$, 三个热平均可显式计算:

$$\langle \xi^1 \xi^2 \rangle = \frac{\partial \ln Z_{\text{eff}}}{\partial b_3} = \frac{\tanh b_3 + \tanh b_1 \tanh b_2}{1 + \tanh b_1 \tanh b_2 \tanh b_3}, \quad (12.73)$$

$$\langle \xi^1 \rangle = \frac{\partial \ln Z_{\text{eff}}}{\partial b_1} = \frac{\tanh b_1 + \tanh b_2 \tanh b_3}{1 + \tanh b_1 \tanh b_2 \tanh b_3}, \quad (12.74)$$

$$\langle \xi^2 \rangle = \frac{\partial \ln Z_{\text{eff}}}{\partial b_2} = \frac{\tanh b_2 + \tanh b_1 \tanh b_3}{1 + \tanh b_1 \tanh b_2 \tanh b_3}. \quad (12.75)$$

若 $\hat{r} < 0$, 可采用等价的实 Gaussian 参数化

$$b_1 = \sqrt{\hat{q}_1} z_1 + \hat{T}_1 \xi^{1, \text{true}} + \hat{\tau}_2 \xi^{2, \text{true}}, \quad (12.76a)$$

$$b_2 = \sqrt{\hat{q}_2} (\psi z_1 + \sqrt{1 - \psi^2} z_2) + \hat{T}_2 \xi^{2, \text{true}} + \hat{\tau}_1 \xi^{1, \text{true}}, \quad (12.76b)$$

$$\psi = \frac{\hat{r}}{2\sqrt{\hat{q}_1 \hat{q}_2}}. \quad (12.76c)$$

该重参数化不改变多维 Gaussian 积分的最终结果.

综上, 非共轭序参量方程为

$$T_1 = [\xi^{1, \text{true}} \langle \xi^1 \rangle], \quad (12.77a)$$

$$T_2 = [\xi^{2, \text{true}} \langle \xi^2 \rangle], \quad (12.77b)$$

$$q_1 = [\langle \xi^1 \rangle^2], \quad (12.77c)$$

$$q_2 = [\langle \xi^2 \rangle^2], \quad (12.77d)$$

$$\tau_1 = [\xi^{1, \text{true}} \langle \xi^2 \rangle], \quad (12.77e)$$

$$\tau_2 = [\xi^{2, \text{true}} \langle \xi^1 \rangle], \quad (12.77f)$$

$$R = [\langle \xi^1 \xi^2 \rangle], \quad (12.77g)$$

$$r = [\langle \xi^1 \rangle \langle \xi^2 \rangle]. \quad (12.77h)$$

这里所有方括号都包含 Gaussian 与真实特征平均.

下面求共轭序参量. 对 $\hat{R}$,

$$\frac{\partial F_\beta}{\partial R} = -\hat{R} - \alpha\beta^2 \tanh(\beta^2 R) + \frac{\alpha e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \frac{\partial \ln Z_E}{\partial R} = 0. \quad (12.78)$$

因 $\partial_R \ln Z_E = \beta^2 G_c^-$,

$$\hat{R} = \frac{\alpha\beta^2 e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_c^- - \alpha\beta^2 \tanh(\beta^2 R). \quad (12.79)$$

定义归一化加权平均

$$\langle\langle A \rangle\rangle = \frac{e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] A,$$

则

$$\hat{R} = \alpha\beta^2 \langle\langle G_c^- \rangle\rangle - \alpha\beta^2 \tanh(\beta^2 R). \quad (12.80)$$

对 $\hat{T}_1$, 驻点条件为

$$\frac{\partial F_\beta}{\partial T_1} = -\hat{T}_1 + \frac{\alpha e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \frac{\partial \ln Z_E}{\partial T_1} = 0. \quad (12.81)$$

$\Theta_\pm$ 对 T_1 的导数为

$$\partial_{T_1} \Theta_+ = t_0 - \frac{q}{\sqrt{1-q^2}} x_0 + \partial_{T_1} \left(B + \frac{r-A}{B} \right) u + (\partial_{T_1} K) u', \quad (12.82a)$$

$$\partial_{T_1} \Theta_- = t_0 - \frac{q}{\sqrt{1-q^2}} x_0 + \partial_{T_1} \left(B - \frac{r-A}{B} \right) u - (\partial_{T_1} K) u'. \quad (12.82b)$$

因而

$$\frac{\partial \ln Z_E}{\partial T_1} = \beta G_s^+ \left(t_0 - \frac{q}{\sqrt{1-q^2}} x_0 \right) + \beta \partial_{T_1} B G_s^+ u + \beta \partial_{T_1} \left(\frac{r-A}{B} \right) G_s^- u + \beta (\partial_{T_1} K) G_s^- u'. \quad (12.83)$$

下列 Gaussian 分部积分恒等式用于化简：

$$\langle G_s^+ t_0 \rangle_w = \beta \left\langle \tanh(\beta t_0) G_s^+ + q \tanh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_s^+ + T_1 + \tau_1 G_c^- - T_1 (G_s^+)^2 - \tau_1 G_s^+ G_s^- \right\rangle_w, \quad (12.84)$$

$$\begin{aligned} \langle G_s^+ x_0 \rangle_w &= \beta \sqrt{1-q^2} \left\langle \tanh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_s^+ \right\rangle_w \\ &+ \frac{\beta}{\sqrt{1-q^2}} \left\langle (\tau_2 - qT_1) + (T_2 - q\tau_1) G_c^- - (\tau_2 - qT_1) (G_s^+)^2 - (T_2 - q\tau_1) G_s^+ G_s^- \right\rangle_w, \end{aligned} \quad (12.85)$$

$$\langle G_s^+ u \rangle_w = \beta \left\langle B + \frac{r-A}{B} G_c^- - B (G_s^+)^2 - \frac{r-A}{B} G_s^+ G_s^- \right\rangle_w, \quad (12.86)$$

$$\langle G_s^- u \rangle_w = \beta \left\langle B G_c^- + \frac{r-A}{B} - \frac{r-A}{B} (G_s^-)^2 - B G_s^+ G_s^- \right\rangle_w, \quad (12.87)$$

$$\langle G_s^- u' \rangle_w = \beta K \langle 1 - (G_s^-)^2 \rangle_w. \quad (12.88)$$

这里 $\langle \cdot \rangle_w$ 表示上述含两个 cosh 权重的 Gaussian 积分。代数消去后，

$$\hat{T}_1 = \frac{\alpha \beta^2 e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \sinh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_s^+. \quad (12.89)$$

再定义

$$\langle\langle A \rangle\rangle_1 = \frac{e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \sinh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] A,$$

则

$$\hat{T}_1 = \alpha \beta^2 \langle\langle G_s^+ \rangle\rangle_1, \quad (12.90)$$

$$\hat{\tau}_1 = \alpha \beta^2 \langle\langle G_s^- \rangle\rangle_1. \quad (12.91)$$

$\Theta_{\pm}$ 对 T_2 的导数为

$$\partial_{T_2} \Theta_+ = \frac{x_0}{\sqrt{1-q^2}} - \frac{\partial_{T_2} A}{B} u + (\partial_{T_2} K) u', \quad (12.92a)$$

$$\partial_{T_2} \Theta_- = -\frac{x_0}{\sqrt{1-q^2}} + \frac{\partial_{T_2} A}{B} u - (\partial_{T_2} K) u'. \quad (12.92b)$$

因此

$$\frac{\partial \ln Z_E}{\partial T_2} = \frac{\beta x_0}{\sqrt{1-q^2}} G_s^- - \frac{\beta}{B} (\partial_{T_2} A) G_s^- u + \beta (\partial_{T_2} K) G_s^- u'. \quad (12.93)$$

直接代入给出

$$\hat{T}_2 = \frac{\alpha \beta e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \left[\frac{x_0 G_s^-}{\sqrt{1-q^2}} - \frac{\partial_{T_2} A}{B} G_s^- u + (\partial_{T_2} K) G_s^- u' \right]. \quad (12.94)$$

还需恒等式

$$\begin{aligned} \langle G_s^- x_0 \rangle_w &= \beta \sqrt{1-q^2} \langle \tanh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_s^- \rangle_w \\ &+ \frac{\beta}{\sqrt{1-q^2}} \langle (\tau_2 - qT_1) G_c^- - (\tau_2 - qT_1) G_s^+ G_s^- - (T_2 - q\tau_1)(G_s^-)^2 + T_2 - q\tau_1 \rangle_w. \end{aligned} \quad (12.95)$$

结合式 (12.87)、(12.88), 得到

$$\hat{T}_2 = \frac{\alpha\beta^2 e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \sinh[\beta(qt_0 + \sqrt{1-q^2}x_0)] G_s^-. \quad (12.96)$$

定义

$$\langle\langle A \rangle\rangle_2 = \frac{e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \sinh[\beta(qt_0 + \sqrt{1-q^2}x_0)] A,$$

则

$$\hat{T}_2 = \alpha\beta^2 \langle\langle G_s^- \rangle\rangle_2, \quad (12.97)$$

$$\hat{\tau}_2 = \alpha\beta^2 \langle\langle G_s^+ \rangle\rangle_2. \quad (12.98)$$

对 q_1 ,

$$\frac{1}{2}\hat{q}_1 - \frac{\alpha\beta^2}{2} + \frac{\alpha e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \frac{\partial \ln Z_E}{\partial q_1} = 0. \quad (12.99)$$

其中

$$\frac{\partial \ln Z_E}{\partial q_1} = \beta(\partial_{q_1} B) G_s^+ u + \beta \partial_{q_1} \left(\frac{r-A}{B} \right) G_s^- u + \beta(\partial_{q_1} K) G_s^- u'. \quad (12.100)$$

消去各导数项后,

$$\hat{q}_1 = \frac{\alpha\beta^2 e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] (G_s^+)^2 = \alpha\beta^2 \langle\langle (G_s^+)^2 \rangle\rangle, \quad (12.101)$$

$$\hat{q}_2 = \frac{\alpha\beta^2 e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] (G_s^-)^2 = \alpha\beta^2 \langle\langle (G_s^-)^2 \rangle\rangle. \quad (12.102)$$

最后, $\hat{r}$ 满足

$$\frac{\hat{r}}{2} + \frac{\alpha e^{-\beta^2}}{\cosh(\beta^2 q)} \int Dt \cosh(\beta t_0) \cosh[\beta(qt_0 + \sqrt{1-q^2}x_0)] \frac{\partial \ln Z_E}{\partial r} = 0, \quad (12.103)$$

从而

$$\hat{r} = 2\alpha\beta^2 \langle\langle G_s^+ G_s^- \rangle\rangle. \quad (12.104)$$

共轭鞍点方程汇总为

$$\hat{T}_1 = \alpha\beta^2 \langle\langle G_s^+ \rangle\rangle_1, \quad (12.105a)$$

$$\hat{T}_2 = \alpha\beta^2 \langle\langle G_s^- \rangle\rangle_2, \quad (12.105b)$$

$$\hat{\tau}_1 = \alpha\beta^2 \langle\langle G_s^- \rangle\rangle_1, \quad (12.105c)$$

$$\hat{\tau}_2 = \alpha\beta^2 \langle\langle G_s^+ \rangle\rangle_2, \quad (12.105d)$$

$$\hat{q}_1 = \alpha\beta^2 \langle\langle (G_s^+)^2 \rangle\rangle, \quad (12.105e)$$

$$\hat{q}_2 = \alpha\beta^2 \langle\langle (G_s^-)^2 \rangle\rangle, \quad (12.105f)$$

$$\hat{r} = 2\alpha\beta^2 \langle\langle G_s^+ G_s^- \rangle\rangle, \quad (12.105g)$$

$$\hat{R} = \alpha\beta^2 \langle\langle G_c^- \rangle\rangle - \alpha\beta^2 \tanh(\beta^2 R). \quad (12.105h)$$

零相关特例. 当真实相关 $q = 0$ 且推断不使用相关先验时, 鞍点解满足 $q_1 = q_2$, $T_1 = T_2$, 其余序参量为零. 此时

$$\Theta_+ = T_1 t_0 + T_2 x_0 + \sqrt{q_1 - T_1^2} u + \sqrt{q_2 - T_2^2} u', \quad (12.106a)$$

$$\Theta_- = T_1 t_0 - T_2 x_0 + \sqrt{q_1 - T_1^2} u - \sqrt{q_2 - T_2^2} u'. \quad (12.106b)$$

令 $\chi_1 = T_1 t_0 + \sqrt{q_1 - T_1^2} u$, $\chi_2 = T_2 x_0 + \sqrt{q_2 - T_2^2} u'$. 则

$$\begin{aligned} \hat{T}_1 &= \alpha\beta^2 e^{-\beta^2} \int Dt \sinh(\beta t_0) \cosh(\beta x_0) \frac{\sinh(\beta\Theta_+) + \sinh(\beta\Theta_-)}{\cosh(\beta\Theta_+) + \cosh(\beta\Theta_-)} \\ &= \alpha\beta^2 e^{-\beta^2/2} \int Dt_0 Du \sinh(\beta t_0) \tanh[\beta(T_1 t_0 + \sqrt{q_1 - T_1^2} u)]. \end{aligned} \quad (12.107)$$

同理 $\hat{T}_1 = \hat{T}_2$, 且

$$\begin{aligned} \hat{q}_1 &= \alpha\beta^2 e^{-\beta^2} \int Dt \cosh(\beta t_0) \cosh(\beta x_0) \left[\frac{\sinh(\beta\Theta_+) + \sinh(\beta\Theta_-)}{\cosh(\beta\Theta_+) + \cosh(\beta\Theta_-)} \right]^2 \\ &= \alpha\beta^2 e^{-\beta^2/2} \int Dt_0 Du \cosh(\beta t_0) \tanh^2[\beta(T_1 t_0 + \sqrt{q_1 - T_1^2} u)]. \end{aligned} \quad (12.108)$$

并有 $\hat{q}_1 = \hat{q}_2$ 以及 $\hat{\tau}_1 = \hat{\tau}_2 = \hat{R} = \hat{r} = 0$, 故

$$b_1 = \hat{T}_1 \xi^{1,\text{true}} + \sqrt{\hat{q}_1} z_1, \quad (12.109a)$$

$$b_2 = \hat{T}_2 \xi^{2,\text{true}} + \sqrt{\hat{q}_2} z_2, \quad (12.109b)$$

$$b_3 = 0. \quad (12.109c)$$

于是

$$T_1 = \int Dz_1 \tanh(\hat{T}_1 + \sqrt{\hat{q}_1} z_1), \quad (12.110)$$

$$q_2 = \int Dz_2 \tanh^2(\hat{T}_2 + \sqrt{\hat{q}_2} z_2). \quad (12.111)$$

同理 $T_1 = T_2$, $q_1 = q_2$, $R = r = \tau_1 = \tau_2 = 0$, 正好恢复单比特 RBM 的鞍点方程. 能量项还满足

$$\alpha e^{-\beta^2} \int Dt \cosh(\beta t_0) \cosh(\beta x_0) \ln Z_E = \alpha \ln 2 + 2\alpha e^{-\beta^2/2} \int Du Dt_0 \cosh(\beta t_0) \ln \cosh[\beta(T_1 t_0 + \sqrt{q_1 - T_1})] \quad (12.112)$$

故 $q = 0$ 时二比特模型的自由能恰为单比特 RBM 的两倍, 等价于 $\Omega = \Omega_{\text{one-bit}}^2$. 新增一个隐藏节点并不改变 SSB 的临界数据量; 按配分函数因子化, 这一结论预期也适用于更多隐藏节点.

含真实相关先验的 Bayes 最优情形. 此时整数副本矩为

$$\begin{aligned} [\Omega^n] &= \sum_{\xi^{\text{true}}, \sigma} \prod_i P_0(\xi_i^{1,\text{true}}, \xi_i^{2,\text{true}}) \prod_a \frac{\cosh(\beta X_a^0) \cosh(\beta Y_a^0)}{2^N e^{\beta^2} \cosh(\beta^2 q)} \\ &\times \sum_{\{\xi^{1,\gamma}, \xi^{2,\gamma}\}} \prod_{a,\gamma} \frac{\cosh(\beta X_a^\gamma) \cosh(\beta Y_a^\gamma)}{\cosh(\beta^2 R^\gamma)} \prod_{i,\gamma} P_0(\xi_i^{1,\gamma}, \xi_i^{2,\gamma}). \end{aligned} \quad (12.113)$$

RS 作用量仍写作 $A = G_0 + G_S + \alpha G_E$, 其中

$$\begin{aligned} G_0 &= -nR\hat{R} - nT_1\hat{T}_1 - nT_2\hat{T}_2 - n\tau_1\hat{\tau}_1 - n\tau_2\hat{\tau}_2 \\ &+ \frac{n(n-1)}{2}(q_1\hat{q}_1 + q_2\hat{q}_2) + \frac{n}{2}r\hat{r}. \end{aligned} \quad (12.114)$$

熵项只是在站点权重中加入先验:

$$G_S = \ln \left[\sum_{\{\xi^{1,\gamma}, \xi^{2,\gamma}\}} \exp \left\{ \sum_{\gamma} [b_1 \xi^{1,\gamma} + b_2 \xi^{2,\gamma} + b_3 \xi^{1,\gamma} \xi^{2,\gamma} + \ln P_0(\xi^{1,\gamma}, \xi^{2,\gamma})] \right\} \right]_{\xi^{1,\text{true}}, \xi^{2,\text{true}}} \quad (12.115)$$

因此

$$G_S = \ln \left[\int D\mathbf{z} \left(\sum_{\xi^1, \xi^2} e^{b_1 \xi^1 + b_2 \xi^2 + b_3 \xi^1 \xi^2 + \ln P_0(\xi^1, \xi^2)} \right) \right]_{\text{true}} - \frac{n}{2}(\hat{q}_1 + \hat{q}_2), \quad (12.116)$$

其中

$$b_1 = \sqrt{\hat{q}_1 - \hat{r}/2} z_1 + \sqrt{\hat{r}/2} z_3 + \hat{T}_1 \xi^{1,\text{true}} + \hat{\tau}_2 \xi^{2,\text{true}}, \quad (12.117a)$$

$$b_2 = \sqrt{\hat{q}_2 - \hat{r}/2} z_2 + \sqrt{\hat{r}/2} z_3 + \hat{T}_2 \xi^{2,\text{true}} + \hat{\tau}_1 \xi^{1,\text{true}}, \quad (12.117b)$$

$$b_3 = \hat{R} - \hat{r}/2. \quad (12.117c)$$

对相关先验 $P_0(\xi^1, \xi^2) = (1 + q\xi^1\xi^2)/4$,

$$\begin{aligned} Z_{\text{eff}} &= \sum_{\xi^1, \xi^2} e^{b_1 \xi^1 + b_2 \xi^2 + b_3 \xi^1 \xi^2} P_0(\xi^1, \xi^2) \\ &= (1 + q)e^{b_3} \cosh(b_1 + b_2) + (1 - q)e^{-b_3} \cosh(b_1 - b_2). \end{aligned} \quad (12.118)$$

非共轭方程仍为

$$T_1 = [\xi^{1,\text{true}} \langle \xi^1 \rangle], \quad (12.119a)$$

$$T_2 = [\xi^{2,\text{true}} \langle \xi^2 \rangle], \quad (12.119b)$$

$$q_1 = [\langle \xi^1 \rangle^2], \quad (12.119c)$$

$$q_2 = [\langle \xi^2 \rangle^2], \quad (12.119d)$$

$$\tau_1 = [\xi^{1,\text{true}} \langle \xi^2 \rangle], \quad (12.119e)$$

$$\tau_2 = [\xi^{2,\text{true}} \langle \xi^1 \rangle], \quad (12.119f)$$

$$R = [\langle \xi^1 \xi^2 \rangle], \quad (12.119g)$$

$$r = [\langle \xi^1 \rangle \langle \xi^2 \rangle]. \quad (12.119h)$$

有效模型下的三类热平均显式为

$$\langle \xi^1 \rangle = \frac{\tanh b_1 + \tanh b_2 \tanh b_3 + q \tanh b_2 + q \tanh b_1 \tanh b_3}{1 + \tanh b_1 \tanh b_2 \tanh b_3 + q \tanh b_3 + q \tanh b_1 \tanh b_2}, \quad (12.120)$$

$$\langle \xi^2 \rangle = \frac{\tanh b_2 + \tanh b_1 \tanh b_3 + q \tanh b_1 + q \tanh b_2 \tanh b_3}{1 + \tanh b_1 \tanh b_2 \tanh b_3 + q \tanh b_3 + q \tanh b_1 \tanh b_2}, \quad (12.121)$$

$$\langle \xi^1 \xi^2 \rangle = \frac{\tanh b_3 + \tanh b_1 \tanh b_2 + q \tanh b_1 \tanh b_2 \tanh b_3 + q}{1 + \tanh b_1 \tanh b_2 \tanh b_3 + q \tanh b_3 + q \tanh b_1 \tanh b_2}. \quad (12.122)$$

共轭方程与无先验情形相同：

$$\hat{T}_1 = \alpha \beta^2 \langle\langle G_s^+ \rangle\rangle_1, \quad (12.123a)$$

$$\hat{T}_2 = \alpha \beta^2 \langle\langle G_s^- \rangle\rangle_2, \quad (12.123b)$$

$$\hat{q}_1 = \alpha \beta^2 \langle\langle (G_s^+)^2 \rangle\rangle, \quad (12.123c)$$

$$\hat{q}_2 = \alpha \beta^2 \langle\langle (G_s^-)^2 \rangle\rangle, \quad (12.123d)$$

$$\hat{\tau}_1 = \alpha \beta^2 \langle\langle G_s^- \rangle\rangle_1, \quad (12.123e)$$

$$\hat{\tau}_2 = \alpha \beta^2 \langle\langle G_s^+ \rangle\rangle_2, \quad (12.123f)$$

$$\hat{R} = \alpha \beta^2 \langle\langle G_c^- \rangle\rangle - \alpha \beta^2 \tanh(\beta^2 R), \quad (12.123g)$$

$$\hat{r} = 2\alpha \beta^2 \langle\langle G_s^+ G_s^- \rangle\rangle. \quad (12.123h)$$

12.1.3 稳定性分析

在连续相变点附近，所有序参量都很小，可对它们作最低阶展开。先考虑无相关先验的推断。由式 (12.77)，临界点下方有 $\langle \xi^1 \rangle \simeq b_1$ 、 $\langle \xi^2 \rangle \simeq b_2$ 、 $\langle \xi^1 \xi^2 \rangle \simeq b_3$ ，因而

$$T_1 = \hat{T}_1 + q \hat{\tau}_2, \quad (12.124)$$

$$\tau_2 = \hat{\tau}_2 + q \hat{T}_1. \quad (12.125)$$

同时

$$G_s^+ \simeq \frac{\beta}{2}(\Theta_+ + \Theta_-). \quad (12.126)$$

代入共轭方程得

$$\begin{aligned}\hat{T}_1 &= \alpha\beta^4[T_1 + \tanh(\beta^2 q)\tau_2], \\ \hat{\tau}_2 &= \alpha\beta^4[\tau_2 + \tanh(\beta^2 q)T_1].\end{aligned}\quad (12.127)$$

四个量可写成矩阵关系

$$\begin{pmatrix} T_1 \\ \tau_2 \end{pmatrix} = \begin{pmatrix} 1 & q \\ q & 1 \end{pmatrix} \begin{pmatrix} \hat{T}_1 \\ \hat{\tau}_2 \end{pmatrix}, \quad (12.128)$$

$$\begin{pmatrix} \hat{T}_1 \\ \hat{\tau}_2 \end{pmatrix} = \alpha\beta^4 \begin{pmatrix} 1 & \tanh(\beta^2 q) \\ \tanh(\beta^2 q) & 1 \end{pmatrix} \begin{pmatrix} T_1 \\ \tau_2 \end{pmatrix}. \quad (12.129)$$

因此

$$\begin{pmatrix} T_1 \\ \tau_2 \end{pmatrix} = \alpha\beta^4 \begin{pmatrix} 1 + q \tanh(\beta^2 q) & q + \tanh(\beta^2 q) \\ q + \tanh(\beta^2 q) & 1 + q \tanh(\beta^2 q) \end{pmatrix} \begin{pmatrix} T_1 \\ \tau_2 \end{pmatrix}. \quad (12.130)$$

稳定性矩阵的两个本征值为

$$\lambda_+ = \alpha\beta^4 [1 + q \tanh(\beta^2 q) + |q + \tanh(\beta^2 q)|], \quad (12.131)$$

$$\lambda_- = \alpha\beta^4 [1 + q \tanh(\beta^2 q) - |q + \tanh(\beta^2 q)|]. \quad (12.132)$$

最大本征值达到一时发生相变：

$$\alpha_c = \frac{\beta^{-4}}{1 + q \tanh(\beta^2 q) + |q + \tanh(\beta^2 q)|}. \quad (12.133)$$

较小本征值给出的阈值与“无噪声数据应更易学习”的物理预期矛盾，故不能决定临界点。

两个极限很有启发性。当 $|q| \rightarrow 1$ 且 β 足够大时， $\alpha_c \rightarrow \beta^{-4}/4$ 。当 $|q| \rightarrow 0$ 但不严格为零，在大 β 下

$$\lim_{\beta \rightarrow \infty} \alpha_c \beta^4 = \begin{cases} 1, & |q| \ll \beta^{-2}, \\ [1 + |\tanh q_0|]^{-1}, & q = q_0 \beta^{-2} \text{ 或 } |q| \sim \beta^{-2}, \\ [2(1 + |q|)]^{-1}, & |q| \gg \beta^{-2}. \end{cases} \quad (12.134)$$

这里 $\beta \rightarrow \infty$ 表示足够大以使相关双曲正切饱和，而非某个实际无限温标。只要两个特征图存在比 β^{-2} 稍大的弱相关，触发学习所需数据量就可显著低于无相关情形。

这一结果提出关于概念形成触发条件的假说：比 β^{-2} 大一些、但仍较小的相关程度，最有利于从较小数据集中无监督学习。局域强制特征正交等正则化已用于深度学习；弱相关感受野还能减少突触权重冗余，使不同特征探测器高效编码刺激而非共同捕捉噪声。机器学习任务和神经科学实验可进一步联合检验最小学习数据量、突触或感受野相关程度与刺激噪声之间的关系。




图 12.2: 临界数据量式 (12.133) 随相关程度 q 的变化. 比较弱特征相关相对于 β^{-2} 的不同量级; 此例 $\beta = 5$, 虚线为式 (12.134) 的第三种情形. 图改编自文献 [1].

在 Bayes 最优推断中, α 从下方接近 SSB 阈值时, 除 $R = q$ 外所有序参量都趋近零, 且阈值以下 $\hat{R} = 0$. 因 $\langle \xi^1 \rangle \simeq b_1 + qb_2$ 、 $\langle \xi^2 \rangle \simeq b_2 + qb_1$, 有

$$T_1 \simeq \hat{T}_1 + q\hat{\tau}_2 + q\hat{\tau}_1 + q^2\hat{T}_2, \quad (12.135a)$$

$$T_2 \simeq \hat{T}_2 + q\hat{\tau}_2 + q\hat{\tau}_1 + q^2\hat{T}_1, \quad (12.135b)$$

$$\tau_1 \simeq \hat{\tau}_1 + q\hat{T}_1 + q\hat{T}_2 + q^2\hat{\tau}_2, \quad (12.135c)$$

$$\tau_2 \simeq \hat{\tau}_2 + q\hat{T}_1 + q\hat{T}_2 + q^2\hat{\tau}_1. \quad (12.135d)$$

令 $W(q) = e^{\beta^2 q} / [2 \cosh(\beta^2 q)]$, $\Upsilon = 2W(q) - 1$. 最低阶还满足

$$\langle\langle \Theta_+ \rangle\rangle_1 = \beta[T_1 + \tau_1 + \tanh(\beta^2 q)(\tau_2 + T_2)], \quad (12.136a)$$

$$\langle\langle \Theta_- \rangle\rangle_1 = \beta[T_1 - \tau_1 + \tanh(\beta^2 q)(\tau_2 - T_2)], \quad (12.136b)$$

$$\langle\langle \Theta_+ \rangle\rangle_2 = \beta[T_2 + \tau_2 + \tanh(\beta^2 q)(\tau_1 + T_1)], \quad (12.136c)$$

$$\langle\langle \Theta_- \rangle\rangle_2 = \beta[\tau_2 - T_2 + \tanh(\beta^2 q)(T_1 - \tau_1)]. \quad (12.136d)$$

从而

$$\hat{T}_1 \simeq \alpha\beta^4[T_1 + \Upsilon\tau_1 + \tanh(\beta^2 q)(\tau_2 + \Upsilon T_2)], \quad (12.137a)$$

$$\hat{T}_2 \simeq \alpha\beta^4[T_2 + \Upsilon\tau_2 + \tanh(\beta^2 q)(\tau_1 + \Upsilon T_1)], \quad (12.137b)$$

$$\hat{\tau}_1 \simeq \alpha\beta^4[\tau_1 + \Upsilon T_1 + \tanh(\beta^2 q)(T_2 + \Upsilon\tau_2)], \quad (12.137c)$$

$$\hat{\tau}_2 \simeq \alpha\beta^4[\tau_2 + \Upsilon T_2 + \tanh(\beta^2 q)(T_1 + \Upsilon\tau_1)]. \quad (12.137d)$$

式 (12.135) 写成

$$\begin{pmatrix} T_1 \\ T_2 \\ \tau_1 \\ \tau_2 \end{pmatrix} = \begin{pmatrix} 1 & q^2 & q & q \\ q^2 & 1 & q & q \\ q & q & 1 & q^2 \\ q & q & q^2 & 1 \end{pmatrix} \begin{pmatrix} \hat{T}_1 \\ \hat{T}_2 \\ \hat{\tau}_1 \\ \hat{\tau}_2 \end{pmatrix}, \quad (12.138)$$

式 (12.137) 写成

$$\begin{pmatrix} \hat{T}_1 \\ \hat{T}_2 \\ \hat{\tau}_1 \\ \hat{\tau}_2 \end{pmatrix} = \alpha\beta^4 \begin{pmatrix} 1 & \Upsilon t & \Upsilon & t \\ \Upsilon t & 1 & t & \Upsilon \\ \Upsilon & t & 1 & \Upsilon t \\ t & \Upsilon & \Upsilon t & 1 \end{pmatrix} \begin{pmatrix} T_1 \\ T_2 \\ \tau_1 \\ \tau_2 \end{pmatrix}, \quad t = \tanh(\beta^2 q). \quad (12.139)$$

稳定性矩阵具有块形式 $\mathcal{M} = \begin{pmatrix} A & B \\ B & A \end{pmatrix}$, 其中

$$A = \alpha\beta^4 \begin{pmatrix} (1 + qt)(1 + q\Upsilon) & (t + q)(q + \Upsilon) \\ (t + q)(q + \Upsilon) & (1 + qt)(1 + q\Upsilon) \end{pmatrix}, \quad (12.140a)$$

$$B = \alpha\beta^4 \begin{pmatrix} (\Upsilon + q)(1 + qt) & (\Upsilon q + 1)(q + t) \\ (\Upsilon q + 1)(q + t) & (\Upsilon + q)(1 + qt) \end{pmatrix}. \quad (12.140b)$$

由块矩阵行列式恒等式,

$$\det(\mathcal{M} - \lambda I) = \det(A + B - \lambda I) \det(A - B - \lambda I), \quad (12.141)$$

亦即本征值分别由

$$\det \left[\alpha \beta^4 (1 - q)(1 - \Upsilon) \begin{pmatrix} 1 + qt & -(q + t) \\ -(q + t) & 1 + qt \end{pmatrix} - \lambda I \right] = 0 \quad (12.142)$$

与相应的 $(1 + q)(1 + \Upsilon)$ 分支决定. 最大本征值为

$$\lambda_{\max} = \alpha \beta^4 (1 + |q|)(1 + |\Upsilon|) [1 + q \tanh(\beta^2 q) + |q + \tanh(\beta^2 q)|],$$

故 Bayes 最优 SSB 临界密度是

$$\alpha_c = \frac{\beta^{-4}}{(1 + |q|)(1 + |\Upsilon|) [1 + q \tanh(\beta^2 q) + |q + \tanh(\beta^2 q)|]}. \quad (12.143)$$




图 12.3: 有、无相关先验时 SSB 临界数据密度的比较. 图改编自文献 [2].

12.2 相图

小 α 时, 除 $R = q$ 外其余序参量的零解稳定, 系统处于随机猜测 (RG) 相. 此时 $\langle \xi^1 \rangle = \langle \xi^2 \rangle = 0$, 权重以相等概率取 ± 1 , 数据还不足以偏置推断方向; 后验在

$(\xi^1, \xi^2) \rightarrow (-\xi^1, -\xi^2)$ 下的反演对称性未破缺. 线性稳定性分析给出

$$\alpha_c = \frac{\Theta(\beta, q)}{(1 + |q|)[1 + |\tanh(\beta^2 q)|]}, \quad \Theta(\beta, q) = \frac{\beta^{-4}}{1 + q \tanh(\beta^2 q) + |q + \tanh(\beta^2 q)|}. \quad (12.144)$$

与无先验情形相比, 先验显著降低阈值; 例如 $q = 0.3, \beta = 1$ 时约为无先验阈值的 60%. 在 $q = q_0 \beta^{-2}$ 的弱相关、大 β 极限, 阈值可降至 $\alpha_c \beta^4 = [1 + |\tanh q_0|]^{-2}$, 当 $q_0 = 1$ 时仅为无相关情形的约 32%.

当 $\alpha > \alpha_c$, RG 相被自发对称破缺 (SSB) 相取代, $\langle \xi^1 \rangle = \langle \xi^2 \rangle \neq 0$. 学生此时只推断出两个植入感受野的共同部分, 学生侧置换对称性仍保持. 随数据继续增加, 序参量 r 到达转折点, 置换对称性也破缺, 进入 PSB 相. 图 12.4 区分两类置换破缺: PSB_s 表示学生意识到自己的两个感受野并不相同; PSB_t 表示学生开始区分教师架构中两个隐藏节点的内禀顺序.




图 12.4: 无监督学习中各种内禀对称破缺示意图. 随 α 增大, 先发生连续的反演对称破缺 (SSB), 学生推断真实感受野的共同部分; 随后发生学生侧置换破缺 PSB_s , 开始推断差异部分; 再随后发生教师侧置换破缺 PSB_t , 能够区分教师两个隐藏节点的顺序. PSB_t 后自由能有两个等价谷, 对应真实顺序 (A, B) 与 (B, A) ; 一般 P 个隐藏节点对应 $P!$ 个谷.

PSB 相有两个等自由能不动点: $q_1 = q_2 = T_1 = T_2$, $\tau_1 = \tau_2 = r$, 或 $q_1 = q_2 = \tau_1 = \tau_2$, $T_1 = T_2 = r$. 它们对应两个可交换的真实排序. 有相关先验时, PSB_s 与 PSB_t 在同一转折点合并; 学生开始区分自身两个感受野差异的同时, 也能识别教师两个感受野的顺序. 先验并不改变无先验情形的 PSB_t 转变点, 因为知道 q 并不能加速对两种真实排

序的选择；它只提高转折前的重叠，并使转折后的 r 更大。大但有限 α 时 $r \rightarrow q$ ，无监督学习完成。

无论是否有先验，数据流都驱动连续的 SSB 与 PSB 相变。这些预测可由单实例消息传递数值模拟验证。若 RBM 有多于两个隐藏神经元，消息传递通常不再有闭式；但第 10 章的模型系综变分平均场理论可处理任意多个隐藏神经元。

12.3 超参数推断

数据集 D 给定时，超参数 β, q 的后验为

$$P(\beta, q | D) = \sum_{\xi^1, \xi^2} \frac{P(D | \beta, q, \xi^1, \xi^2) P_0(\xi^1, \xi^2 | q)}{\int d\beta dq \sum_{\xi^1, \xi^2} P(D | \beta, q, \xi^1, \xi^2) P_0(\xi^1, \xi^2 | q)}. \quad (12.145)$$

这里假定 β, q 本身的先验为常数，故

$$P(\beta, q | D) \propto \sum_{\xi^1, \xi^2} \prod_{a=1}^M P(\sigma^a | \beta, q, \xi^1, \xi^2) \prod_{i=1}^N P_0(\xi_i^1, \xi_i^2 | q). \quad (12.146)$$

数据分布为

$$P(\sigma^a | \beta, q, \xi^1, \xi^2) = \frac{\cosh(\beta \xi^1 \cdot \sigma^a / \sqrt{N}) \cosh(\beta \xi^2 \cdot \sigma^a / \sqrt{N})}{2^N e^{\beta^2 Q} \cosh(\beta^2 Q)}. \quad (12.147)$$

因此 $P(\beta, q | D) \propto e^{-M\beta^2} \Omega$ ，其中

$$\Omega(\beta, q) = \sum_{\xi^1, \xi^2} \prod_{a=1}^M \frac{\cosh(\beta \xi^1 \cdot \sigma^a / \sqrt{N}) \cosh(\beta \xi^2 \cdot \sigma^a / \sqrt{N})}{\cosh(\beta^2 Q)} \prod_i P_0(\xi_i^1, \xi_i^2 | q). \quad (12.148)$$

最大化后验等价于寻找与数据自洽的 (β, q) 。温度条件为

$$\frac{\partial \ln P(\beta, q | D)}{\partial \beta} = -2M\beta + \frac{\partial \ln \Omega}{\partial \beta}. \quad (12.149)$$

因统计物理能量密度满足 $N\epsilon = -\partial_\beta \ln \Omega$ ，故

$$\beta = -\frac{\epsilon(\beta, q)}{2\alpha}. \quad (12.150)$$


采用真实先验时 $\epsilon = -2\alpha\beta$ ，与 q 无关，这是 Nishimori 模型的解析能量性质。

Bethe 近似下 $N\epsilon = -\sum_i \epsilon_i + (N-1) \sum_a \epsilon_a$ 。成对突触的能量贡献为


$$\epsilon_i = \frac{\sum_{\xi_i^1, \xi_i^2} [\sum_{b \in \partial i} \partial_\beta u_{b \rightarrow i}(\xi_i^1, \xi_i^2)] e^{\sum_b u_{b \rightarrow i} + \ln P_0(\xi_i^1, \xi_i^2)}}{\sum_{\xi_i^1, \xi_i^2} e^{\sum_b u_{b \rightarrow i} + \ln P_0(\xi_i^1, \xi_i^2)}}. \quad (12.151)$$

其中

$$\begin{aligned} \beta \partial_\beta u_{b \rightarrow i} &= \beta^2 (\Gamma_1^{b \rightarrow i} + \Gamma_2^{b \rightarrow i} + 2\Xi^{b \rightarrow i}) - 2\beta^2 \left(Q_{b \rightarrow i} + \frac{\xi_i^1 \xi_i^2}{N} \right) \tanh \left[\beta^2 Q_{b \rightarrow i} + \frac{\beta^2 \xi_i^1 \xi_i^2}{N} \right] \\ &+ Y_{b \rightarrow i} \tanh Y_{b \rightarrow i} + \frac{\Delta_{b \rightarrow i}}{1 + \Delta_{b \rightarrow i}} \left[-4\beta^2 \Xi^{b \rightarrow i} + X_{b \rightarrow i} \tanh X_{b \rightarrow i} - Y_{b \rightarrow i} \tanh Y_{b \rightarrow i} \right]. \end{aligned} \quad (12.152)$$



(a)



(b)

图 12.5: 含先验无监督学习的相图. (a) $(\beta, q) = (1.0, 0.3)$ 时序参量随数据密度变化; 线为副本结果, 符号为 $N = 200$ 的消息传递实例, 同时比较无先验结果, 箭头表示先验对转变点的移动. (b) 随 β 变化的 SSB 与 PSB 临界数据密度. 图改编自文献 [2].

这里

$$X_{b \rightarrow i} = \beta(G_{b \rightarrow i}^1 - G_{b \rightarrow i}^2) + \frac{\beta \sigma_i^b(\xi_i^1 - \xi_i^2)}{\sqrt{N}}, \quad Y_{b \rightarrow i} = \beta(G_{b \rightarrow i}^1 + G_{b \rightarrow i}^2) + \frac{\beta \sigma_i^b(\xi_i^1 + \xi_i^2)}{\sqrt{N}}, \quad \Delta_{b \rightarrow i} = e^{-2\beta^2 \Xi_{b \rightarrow i}} \frac{\cosh X_{b \rightarrow i}}{\cosh Y_{b \rightarrow i}}$$

单个数据样本的贡献为

$$\begin{aligned} \beta \epsilon_a &= \beta^2(\Gamma_1^a + \Gamma_2^a + 2\Xi^a) - 2\beta^2 Q_a \tanh(\beta^2 Q_a) + Y_a \tanh Y_a \\ &+ \frac{\Delta_a}{1 + \Delta_a} [-4\beta^2 \Xi^a + X_a \tanh X_a - Y_a \tanh Y_a], \end{aligned} \quad (12.153)$$

其中 $X_a = \beta(G_a^1 - G_a^2)$ 、 $Y_a = \beta(G_a^1 + G_a^2)$ 、 $\Delta_a = e^{-2\beta^2 \Xi^a} \cosh X_a / \cosh Y_a$.

对相关参数，写 $P_0(\xi_i^1, \xi_i^2) = e^{J_0 \xi_i^1 \xi_i^2} / [4 \cosh J_0]$ ， $J_0 = \tanh^{-1} q$. 驻点条件是

$$\frac{\partial P(\beta, q \mid D)}{\partial q} = e^{-M\beta^2} \frac{\partial \Omega}{\partial q} = 0. \quad (12.154)$$

而

$$\frac{\partial \Omega}{\partial q} = \Omega \left[\sum_i \langle \xi_i^1 \xi_i^2 \rangle - N \tanh J_0 \right] \frac{\partial J_0}{\partial q} = 0, \quad (12.155)$$

所以

$$q = \frac{1}{N} \sum_i q_i, \quad (12.156)$$

其中

$$q_i = \frac{\sum_{\xi_i^1, \xi_i^2} \xi_i^1 \xi_i^2 e^{\sum_b u_{b \rightarrow i}(\xi_i^1, \xi_i^2)} P_0(\xi_i^1, \xi_i^2)}{\sum_{\xi_i^1, \xi_i^2} e^{\sum_b u_{b \rightarrow i}(\xi_i^1, \xi_i^2)} P_0(\xi_i^1, \xi_i^2)}. \quad (12.157)$$

超参数后验的每神经元负对数似然还可估计为 $\mathcal{L}/N = C - \ln \Omega/N + \alpha \beta^2$ ，其中常数 C 无关，第二项由 Bethe 自由能近似. 仅给数据时，可交替施加两个 Nishimori 自洽条件来推断 (β, q) ：消息更新并计算 $(\epsilon, \{q_i\})$ 是 E 步，超参数更新是 M 步，即期望最大化算法 [8]. 数据不足时超参数景观通常高度非凸，因此会出现较大的相对推断误差与波动.

参考文献

- [1] T. Hou, K. Y. M. Wong, and H. Huang, J. Phys. A: Math. Theor. **52**(41), 414001 (2019).
- [2] T. Hou and H. Huang, Phys. Rev. Lett. **124**, 248302 (2020).
- [3] H. Huang and T. Toyozumi, Phys. Rev. E **94**, 062310 (2016).
- [4] P. Rodriguez et al., in *ICLR 2017* (2016), arXiv:1611.01967.
- [5] H. Huang, Phys. Rev. E **98**, 062313 (2018).
- [6] H. Huang, J. Stat. Mech.: Theory Exper. **2017**(5), 053302 (2017).
- [7] A. Barra, G. Genovese, P. Sollich, and D. Tantari, Phys. Rev. E **96**, 042156 (2017).
- [8] A. P. Dempster, N. M. Laird, and D. B. Rubin, J. R. Stat. Soc. Ser. B **39**, 1 (1977).

Ising 感知机的平均场理论

学习问题要求在含 N 个神经元的网络中找到一组能够存储 P 个模式的突触. 对前馈结构, 它也可视为对带指定标签的 P 个模式进行分类. 为此可构造仅有一个输出单元、输入与输出之间由二元突触连接的最简架构. 虽然这种二元感知机不适于复杂学习 (如非线性可分数据集), 它作为玩具模型在统计物理界受到广泛关注, 并带来了许多重要理论认识. 本章介绍近年来 Ising / 二元感知机理论研究的若干重要进展 [1, 2, 3].

13.1 Ising 感知机模型

物理学家自 20 世纪 80 年代起研究感知机 [4], 最先把连续权重作为统计力学问题分析. 从信息存储角度, 容量定义为机器可正确分类的随机模式数与输入神经元数之最大比值 α_c , 连续权重情形给出 $\alpha_c = 2$ [5]. 随后推广到具有二元 (± 1) 突触的 Ising 型感知机, 其容量低于信息论上界 1 [6, 7, 8]. 球形连续权重感知机在容量以下具有连续解空间, 因而容易训练; 二元感知机却具有彼此孤立的平衡解 [2], 且最坏情形下的训练属于 NP 完全问题 [9, 10].

Ising 感知机是生物神经网络 (如小脑 Purkinje 细胞) 的一种简单抽象模型. 其输出是输入加权之和的符号 (图 13.1):

$$y^\mu = \text{sgn} \left(\sum_i \xi_i^\mu J_i \right). \quad (13.1)$$

这里 ξ_i^μ 是第 μ 个模式的第 i 个分量, J_i 是第 i 个突触, $\text{sgn}(\cdot)$ 是符号函数. 模式各分量以相同概率随机选取, 即 $P(\xi_i^\mu = \pm 1) = 1/2$, 标签也随机且独立于输入. 若标签由教师感知机生成, 问题会变成泛化问题 [11]; 本章不再分析该情形, 因为这里的方法可以直接推广, 而其中会出现有趣的一阶学习转变 [12, 13].

若输出 y^μ 等于预设标签 σ^μ , 便称感知机成功分类 ξ^μ . 网络的能量代价为

$$E(\mathbf{J}) = \sum_{\mu=1}^P \Theta \left(-\frac{\sigma^\mu}{\sqrt{N}} \sum_i J_i \xi_i^\mu \right). \quad (13.2)$$

E 从 0 到 P : 完整存储时为 0, 学习完全失败时为 P . 目标是在神经相互作用空间中寻找使 E 最小的最优 $\mathbf{J}$. 其联合分布写作 Boltzmann–Gibbs 形式

$$P(\mathbf{J}) = \frac{1}{Z} \exp[-\beta E(\mathbf{J})], \quad (13.3)$$

其中逆温 β 表征学习噪声. 零温极限下,

$$P(\mathbf{J}) = \frac{1}{Z} \prod_{\mu} \Theta \left(\frac{\sigma^\mu}{\sqrt{N}} \sum_i J_i \xi_i^\mu \right). \quad (13.4)$$

因而 $\ln Z$ 计数所有有效 $\mathbf{J}$ 的数目，即定义熵 S ；式 (13.4) 也表示对整个解空间的均匀采样. 随模式数 P 增大，要同时满足的约束增多，解数预期下降. 下文取 P, N 均很大但模式密度 $\alpha = P/N$ 有限，研究 S 随 α 的变化及其决定的最大密度（容量）.




图 13.1: 左: 具有三个突触的二元感知机. 右: 二元感知机的因子图; 圆形（变量节点）表示突触，方形（函数节点）表示待学习模式.

13.2 基于消息传递的学习

求 (S) 需要计算配分函数 (Z), 但大 (N) 时直接计算不现实. 消息传递是统计物理 Bethe 近似的应用, 能以小得多的计算量近似配分函数, 第二章已经介绍过. 在此近似下, 联合分布分解为各模式因子的乘积 (另有依赖于位点的归一化因子). 由图 13.1 的因子图得到 [1]

$$P_{i \rightarrow a}(J_i) = \frac{1}{Z_{i \rightarrow a}} \prod_{b \in \partial i \setminus a} \hat{P}_{b \rightarrow i}(J_i), \quad (13.5a)$$

$$\hat{P}_{b \rightarrow i}(J_i) = \sum_{\{J_j: j \in \partial b \setminus i\}} \Theta \left(\frac{\sigma^b}{\sqrt{N}} \sum_j J_j \xi_j^b \right) \prod_{j \in \partial b \setminus i} P_{j \rightarrow b}(J_j). \quad (13.5b)$$

其中 $Z_{i \rightarrow a} = \prod_{b \neq a} \hat{P}_{b \rightarrow i}(+1) + \prod_{b \neq a} \hat{P}_{b \rightarrow i}(-1)$. 式 (13.5b) 要对 2^{N-1} 个构型求和, 实践中不可行. 该求和正是因子项在腔分布下的平均, 故

$$\hat{P}_{b \rightarrow i}(J_i) = \sum_{\mathbf{J}_{\setminus i}} f(\mathbf{J}_{\setminus i}) P(\mathbf{J}_{\setminus i}). \quad (13.6)$$

若找到在大 N 极限连续的辅助变量 $w(\mathbf{J}_{\setminus i})$, 并令 $g[w(\mathbf{J}_{\setminus i})] = f(\mathbf{J}_{\setminus i})$, 则离散求和可近似为

$$\hat{P}_{b \rightarrow i}(J_i) \simeq \int dw P(w) g(w). \quad (13.7)$$

自然地定义 $w_{b \rightarrow i} = N^{-1/2} \sum_{j \in \partial b \setminus i} J_j \xi_j^b$. 因变换 $\xi_i^b \rightarrow \sigma^b \xi_i^b$ 不改变学习设定, 以下不失一般性地令所有模式 $\sigma^b = 1$. 于是

$$\hat{P}_{b \rightarrow i}(J_i) \simeq \int dw_{b \rightarrow i} P(w_{b \rightarrow i}) \Theta \left(w_{b \rightarrow i} + \frac{J_i \xi_i^b}{\sqrt{N}} \right). \quad (13.8)$$

由中心极限定理, $w_{b \rightarrow i} \sim \mathcal{N}(\hat{w}_{b \rightarrow i}, \hat{\sigma}_{b \rightarrow i})$, 其中

$$\hat{w}_{b \rightarrow i} = \frac{1}{\sqrt{N}} \sum_{j \neq i} m_{j \rightarrow b} \xi_j^b, \quad (13.9a)$$

$$\hat{\sigma}_{b \rightarrow i} = \frac{1}{N} \sum_{j \neq i} (1 - m_{j \rightarrow b}^2). \quad (13.9b)$$

注意 $P(w_{b \rightarrow i}) = (2\pi\hat{\sigma}_{b \rightarrow i})^{-1/2} \exp[-(w_{b \rightarrow i} - \hat{w}_{b \rightarrow i})^2/(2\hat{\sigma}_{b \rightarrow i})]$, 且阶跃函数在宗量小于零时为零, 所以

$$\hat{P}_{b \rightarrow i}(J_i) = H \left[-\frac{J_i \xi_i^b / \sqrt{N} + \hat{w}_{b \rightarrow i}}{\sqrt{\hat{\sigma}_{b \rightarrow i}}} \right], \quad (13.10)$$

这里 $H(x) = \int_x^\infty Dz = [1 - \text{erf}(x/\sqrt{2})]/2$, 且 $Dz = e^{-z^2/2} dz / \sqrt{2\pi}$.

再定义腔磁化 $m_{i \rightarrow a} = P_{i \rightarrow a}(+1) - P_{i \rightarrow a}(-1)$, 便有

$$m_{i \rightarrow a} = \tanh \left[\sum_{b \neq a} \frac{1}{2} \ln \frac{\hat{P}_{b \rightarrow i}(+1)}{\hat{P}_{b \rightarrow i}(-1)} \right]. \quad (13.11)$$

最终消息传递方程为

$$m_{i \rightarrow a} = \tanh \left(\sum_{b \neq a} u_{b \rightarrow i} \right), \quad (13.12a)$$

$$u_{b \rightarrow i} = \frac{1}{2} \left\{ \ln H \left[-\frac{\xi_i^b / \sqrt{N} + \hat{w}_{b \rightarrow i}}{\sqrt{\hat{\sigma}_{b \rightarrow i}}} \right] - \ln H \left[-\frac{-\xi_i^b / \sqrt{N} + \hat{w}_{b \rightarrow i}}{\sqrt{\hat{\sigma}_{b \rightarrow i}}} \right] \right\}. \quad (13.12b)$$

与此同时, Bethe 自由能为

$$\beta F = \sum_i \beta F_i - (N-1) \sum_a \beta F_a, \quad (13.13)$$

$$\beta F_i = -\ln \left[\prod_b \hat{P}_{b \rightarrow i}(+1) + \prod_b \hat{P}_{b \rightarrow i}(-1) \right], \quad (13.14)$$

$$\beta F_a = -\ln H \left(-\frac{\hat{w}_b}{\sqrt{\hat{\sigma}_b}} \right). \quad (13.15)$$

其中 $\hat{w}_b = N^{-1/2} \sum_j m_{j \rightarrow b} \xi_j^b$, $\hat{\sigma}_b = N^{-1} \sum_j (1 - m_{j \rightarrow b}^2)$. 能量为零时, 熵恰为 $-\beta F$, 故

$$s = \frac{S}{N} = -\frac{\beta F}{N}. \quad (13.16)$$

图 13.2 给出熵随模式密度的变化. 两个检验是: 其一, $\alpha = 0$ 时每个突触可任取, 构型数为 2^N , 故熵为 $\ln 2$; 其二, 熵关于 α 的曲线必须凹. 数值结果确认熵单调下降; 熵变负的容量约为 0.833, 下一节用副本理论精确计算.




图 13.2: 熵随模式密度变化. 结果来自对 ($N=1000$) 的单个实例运行消息传递 (MP) 算法, 并对 20 个随机实现统计.

13.3 副本分析

MP 只对给定模式近似估计容量, 模式选择造成的涨落使有限 (N) 下难以得到精确且与 (N) 无关的容量. 因此改用副本法计算对所有随机模式实现平均后的自由能. 副本技巧为

$$\overline{\ln Z} = \lim_{n \rightarrow 0} \frac{\ln \overline{Z^n}}{n}, \quad (13.17)$$

横线表示对随机模式的淬火无序平均. 复制原系统 (n) 次后, 妨碍解析研究的突触相关性转化成副本之间的相关性: 突触被解耦, 但须引入各副本之间的重叠. 于是

$$\overline{Z^n} = \sum_{\{\mathbf{J}^a\}} \overline{\prod_{a=1}^n \prod_{\mu=1}^P \Theta \left(\frac{1}{\sqrt{N}} \mathbf{J}^a \cdot \boldsymbol{\xi}^\mu \right)}. \quad (13.18)$$

定义加权

$$u_a^\mu = \frac{1}{\sqrt{N}} \mathbf{J}^a \cdot \boldsymbol{\xi}^\mu, \quad (13.19)$$

其均值与协方差为

$$\overline{u_a^\mu} = 0, \quad (13.20)$$

$$\overline{u_a^\mu u_b^\nu} = \delta_{\mu\nu} q^{ab}, \quad q^{ab} = \frac{1}{N} \sum_i J_i^a J_i^b. \quad (13.21)$$

用 delta 函数引入重叠序参量,

$$\overline{Z^n} = \sum_{\{\mathbf{J}^a\}} \prod_{a < b} \int dq^{ab}, \delta \left(\sum_i J_i^a J_i^b - N q^{ab} \right) \overline{\prod_{\mu=1}^P \prod_{a=1}^n \Theta(u_a^\mu)}. \quad (13.22)$$

利用 Fourier 表示 $\delta(x - a) = \int d\hat{q}/(2\pi) \exp[i(x - a)\hat{q}]$, 可写为

$$\overline{Z^n} = \sum_{\{\mathbf{J}^a\}} \prod_{a < b} \int \frac{dq^{ab} d\hat{q}^{ab}}{2\pi} \exp \left[-iN \sum_{a < b} q^{ab} \hat{q}^{ab} + i \sum_{a < b} \hat{q}^{ab} \mathbf{J}^a \cdot \mathbf{J}^b \right] \overline{\prod_{\mu,a} \Theta(u_a^\mu)}. \quad (13.23)$$

13.3.1 副本对称

为得到物理结果, 需要假设重叠矩阵的形式. 副本对称 (RS) 假设认为重叠元不依赖具体副本指标, 即矩阵具有置换对称性:

$$q^{ab} = \delta_{ab} + (1 - \delta_{ab})q. \quad (13.24)$$

在这一层近似下,

$$\sum_{a < b} q^{ab} \hat{q}^{ab} = \frac{n(n-1)}{2} q \hat{q}, \quad (13.25a)$$

$$\sum_{a < b} \hat{q}^{ab} \mathbf{J}^a \cdot \mathbf{J}^b = \frac{\hat{q}}{2} \sum_i \left[\left(\sum_a J_i^a \right)^2 - n \right]. \quad (13.25b)$$

作变量变换 $\hat{q} \rightarrow i\hat{q}$, 有

$$\overline{Z^n} = \int \frac{dq, d\hat{q}}{2\pi i} \exp \left[-\frac{Nn(n-1)}{2} q \hat{q} \right] \sum_{\{\mathbf{J}^a\}} \exp \left\{ \frac{\hat{q}}{2} \sum_i \left[\left(\sum_a J_i^a \right)^2 - n \right] \right\} \overline{\prod_{\mu,a} \Theta(u_a^\mu)}. \quad (13.26)$$

用 Gaussian 恒等式 $\int Dz e^{bz} = e^{b^2/2}$, 熵项化为

$$\begin{aligned} \mathcal{A} &\equiv \sum_{\{\mathbf{J}^a\}} \exp \left\{ \frac{\hat{q}}{2} \sum_i \left[\left(\sum_a J_i^a \right)^2 - n \right] \right\} \\ &= \left\{ e^{-n\hat{q}/2} \int Dz [2 \cosh(\sqrt{\hat{q}}z)]^n \right\}^N. \end{aligned} \quad (13.27)$$

不同模式的 u_a^μ 独立, 因此能量项为

$$\mathcal{E} \equiv \overline{\prod_{\mu=1}^P \prod_{a=1}^n \Theta(u_a^\mu)} = \left[\overline{\prod_{a=1}^n \Theta(u_a)} \right]^P. \quad (13.28)$$

RS 下 $\overline{u_a} = 0$ 、 $\overline{u_a u_b} = \delta_{ab} + (1 - \delta_{ab})q$. 由中心极限定理, 可令 $u_a = \sqrt{1-q}x_a + \sqrt{q}z$, 其中各 x_a 与 z 为独立标准 Gaussian 变量, 故

$$\begin{aligned}\mathcal{E} &= \left\{ \int Dz \prod_{a=1}^n \int Dx_a, \Theta(\sqrt{1-q}x_a + \sqrt{q}z) \right\}^P \\ &= \left\{ \int Dz \left[H \left(-\sqrt{\frac{q}{1-q}}z \right) \right]^n \right\}^P.\end{aligned}\quad (13.29)$$

合并两项,

$$\begin{aligned}\overline{Z^n} &= \int \frac{dq, d\hat{q}}{2\pi i} \exp \left[-\frac{Nn(n-1)}{2}q\hat{q} - \frac{Nn}{2}\hat{q} + N \ln \int Dz [2 \cosh(\sqrt{\hat{q}}z)]^n \right] \\ &\quad \times \exp \left\{ N\alpha \ln \int Dz \left[H \left(-\sqrt{\frac{q}{1-q}}z \right) \right]^n \right\}.\end{aligned}\quad (13.30)$$

定义指数中的函数后, RS 自由能可写作

$$-\beta f_{\text{RS}} = \lim_{n \rightarrow 0} \frac{\ln \overline{Z^n}}{Nn} = \lim_{n \rightarrow 0} \frac{1}{Nn} \ln \int \frac{dq, d\hat{q}}{2\pi i} e^{N\mathcal{F}(q, \hat{q}, n)}.\quad (13.31)$$

在大 N 极限应用 Laplace 近似,

$$\begin{aligned}-\beta f_{\text{RS}} &= \frac{1}{2}q\hat{q} - \frac{1}{2}\hat{q} + \lim_{n \rightarrow 0} \frac{1}{n} \ln \int Dz [2 \cosh(\sqrt{\hat{q}}z)]^n \\ &\quad + \alpha \lim_{n \rightarrow 0} \frac{1}{n} \ln \int Dz \left[H \left(-\sqrt{\frac{q}{1-q}}z \right) \right]^n.\end{aligned}\quad (13.32)$$

用 L'Hospital 法则取极限, 得到

$$-\beta f_{\text{RS}} = \frac{1}{2}q\hat{q} - \frac{1}{2}\hat{q} + \int Dz \ln[2 \cosh(\sqrt{\hat{q}}z)] + \alpha \int Dz \ln H \left(-\sqrt{\frac{q}{1-q}}z \right).\quad (13.33)$$

利用 Gaussian 分部积分 $\int Dz, F(z)z = \int Dz, F'(z)$ 、 $\tanh'(x) = 1 - \tanh^2 x$ 及 $H'(y) = -e^{-y^2/2}/\sqrt{2\pi}$, 鞍点条件为

$$\begin{aligned}0 &= \frac{\partial(-\beta f_{\text{RS}})}{\partial \hat{q}} = \frac{1}{2}q - \frac{1}{2} \int Dz \tanh^2(\sqrt{\hat{q}}z), \\ 0 &= \frac{\partial(-\beta f_{\text{RS}})}{\partial q} = \frac{1}{2}\hat{q} - \frac{\alpha}{2(1-q)} \int Dz \left[\frac{H'(-\sqrt{q/(1-q)}z)}{H(-\sqrt{q/(1-q)}z)} \right]^2.\end{aligned}\quad (13.34)$$

从而最终的感知机鞍点方程为

$$\begin{aligned}q &= \int Dz \tanh^2(\sqrt{\hat{q}}z), \\ \hat{q} &= \frac{\alpha}{1-q} \int Dz \left[\frac{H'(-\sqrt{q/(1-q)}z)}{H(-\sqrt{q/(1-q)}z)} \right]^2.\end{aligned}\quad (13.35)$$

图 13.3 表明, 当 $\alpha > \alpha_c \simeq 0.833$ 时, 鞍点解给出负熵, 对离散状态变量系统而言不再物理 [8]. 进一步检验 AT 稳定性条件可得 $\alpha_{\text{AT}} \simeq 1.015$ [6, 14]; 因此 RS 解在负熵区仍然稳定. 更深入的理解需要下一小节的副本对称破缺.⁶

⁶有趣的是, MP 算法固定点附近的微观不稳定条件与平衡态中打破 RS 的不稳定条件完全相同; 原书把证明留作练习.




图 13.3: 熵随模式密度变化.RS 理论与在 (N=1000) 的单个学习实例上运行 MP 的结果 (符号) 比较, 共取 20 个随机实例; 虚线标示 (S=0).

13.3.2 副本对称破缺

考虑一步副本对称破缺 (1RSB) 假设. 重叠矩阵 Q 被分成 $n/m \times n/m$ 个宽度为 m 的小块: 对角元按定义为 1, 同一小块内非对角元为 q_1 , 不同小块之间为 q_0 . 例如 $n = 6, m = 2$ 时,

$$Q = \begin{pmatrix} 1 & q_1 & q_0 & q_0 & q_0 & q_0 \\ q_1 & 1 & q_0 & q_0 & q_0 & q_0 \\ q_0 & q_0 & 1 & q_1 & q_0 & q_0 \\ q_0 & q_0 & q_1 & 1 & q_0 & q_0 \\ q_0 & q_0 & q_0 & q_0 & 1 & q_1 \\ q_0 & q_0 & q_0 & q_0 & q_1 & 1 \end{pmatrix}.$$

q_1 是同一状态内副本的平均重叠, q_0 是不同状态副本的平均重叠, 因而 $q_0 < q_1$. 1RSB 下,

$$\overline{Z^n} = \int \prod_{a < b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi} \exp \left[-N \sum_{a < b} q^{ab} \hat{q}^{ab} \right] \sum_{\{J^a\}} \exp \left(\sum_{a < b} \hat{q}^{ab} J^a \cdot J^b \right) \prod_{\mu, a} \overline{\Theta(u_a^\mu)}. \quad (13.36)$$

指数第一部分为

$$\sum_{a < b} q^{ab} \hat{q}^{ab} = \frac{n(m-1)}{2m} q_1 \hat{q}_1 + \frac{n(n-m)}{2m} q_0 \hat{q}_0. \quad (13.37)$$

而突触项中的求和可重写为

$$\sum_{a < b} \hat{q}^{ab} J^a \cdot J^b = \frac{\hat{q}_0}{2} \sum_i \left[\left(\sum_{a=1}^n J_i^a \right)^2 - n \right] + \frac{\hat{q}_1 - \hat{q}_0}{2} \sum_i \sum_c \left[\left(\sum_{a \in c} J_i^a \right)^2 - m \right]. \quad (13.38)$$

依次引入整组共享的标准 Gaussian 变量 z_0 及每一小块共享的 z_1 , 熵项显式算得

$$\mathcal{B} = \exp\left(-\frac{nN\hat{q}_1}{2}\right) \left\{ \int Dz_0 \left[\int Dz_1 \left(2 \cosh \left[\sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right] \right)^m \right]^{n/m} \right\}^N. \quad (13.39)$$

由于不同模式仍然独立, 能量项为

$$\mathcal{E}_{\text{1RSB}} = \left[\prod_{a=1}^n \Theta(u_a) \right]^P. \quad (13.40)$$

其层级协方差结构是

$$\overline{u_a} = 0, \quad \overline{u_a u_b} = \begin{cases} 1, & a = b, \\ q_1, & a \neq b \text{ 且属于同一小块}, \\ q_0, & \text{其他情形}. \end{cases} \quad (13.41)$$

令 $u_a = AX_a + BY_c + CZ$, 其中 X_a, Y_c, Z 相互独立且为标准 Gaussian 变量, 系数须满足

$$A^2 + B^2 + C^2 = 1, \quad B^2 + C^2 = q_1, \quad C^2 = q_0. \quad (13.42)$$

所以 $u_a = \sqrt{1 - q_1}X_a + \sqrt{q_1 - q_0}Y_c + \sqrt{q_0}Z$, 从而

$$\mathcal{E}_{\text{1RSB}} = \left\{ \int DZ \left[\int DY H^m \left(-\frac{\sqrt{q_1 - q_0}Y + \sqrt{q_0}Z}{\sqrt{1 - q_1}} \right) \right]^{n/m} \right\}^P. \quad (13.43)$$

应用 Laplace 近似, 得到

$$\begin{aligned} \frac{1}{N} \ln \overline{Z^n} = & -\frac{n(m-1)}{2m} q_1 \hat{q}_1 - \frac{n(n-m)}{2m} q_0 \hat{q}_0 - \frac{n}{2} \hat{q}_1 \\ & + \ln \int Dz_0 \left[\int Dz_1 \{ 2 \cosh(\sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1) \}^m \right]^{n/m} \\ & + \alpha \ln \int DZ \left[\int DY H^m \left(-\frac{\sqrt{q_1 - q_0}Y + \sqrt{q_0}Z}{\sqrt{1 - q_1}} \right) \right]^{n/m}. \end{aligned} \quad (13.44)$$

取 $n \rightarrow 0$, 1RSB 自由能为

$$\begin{aligned} -\beta f_{\text{1RSB}} = & \frac{1-m}{2} q_1 \hat{q}_1 + \frac{m}{2} q_0 \hat{q}_0 - \frac{1}{2} \hat{q}_1 \\ & + \frac{1}{m} \int Dz_0 \ln \int Dz_1 \{ 2 \cosh(\sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1) \}^m \\ & + \frac{\alpha}{m} \int DZ \ln \int DY H^m \left(-\frac{\sqrt{q_1 - q_0}Y + \sqrt{q_0}Z}{\sqrt{1 - q_1}} \right). \end{aligned} \quad (13.45)$$

由于 $n \rightarrow 0$, 这里 $m \in [0, 1]$, 称为 1RSB 分析的 Parisi 参数 [15]. 鞍点方程由

$$\frac{\partial(-\beta f)}{\partial q_0} = \frac{\partial(-\beta f)}{\partial \hat{q}_0} = \frac{\partial(-\beta f)}{\partial q_1} = \frac{\partial(-\beta f)}{\partial \hat{q}_1} = \frac{\partial(-\beta f)}{\partial m} = 0 \quad (13.46)$$

给出, 其中 (f) 指真实自由能的 1RSB 近似值.

从 RS 到 RSB 的转变发生在零熵线 $S_{\text{RS}}(\alpha, T) = 0$ 上, 这里通过式 (13.3) 引入温度参数. 它也称冻结 RSB 解, 广泛存在于约束满足问题 [16]. 转变是一阶的: 转变点上 $q_1 = 1$ 成为 RSB 解 [8], 并意味着 $\hat{q}_1 \rightarrow \infty$. 进一步有

$$F_{\text{1RSB}}(q_0, \hat{q}_0, 1, \infty, \beta, m) = \frac{1}{m} F_{\text{RS}}(q_0, m^2 \hat{q}_0, \beta m), \quad (13.47)$$

其中 $F \equiv -\beta f$, $m = \beta_c / \beta$, β_c 由零熵条件决定. 关于 m 的驻定条件也约化成零熵条件. 当 $T < T_c$ 时, 自由能等于 β_c 处的 RS 自由能且与温度无关, 类似随机能量模型. 序参量分布为 [8]

$$P(q) = m\delta(q - q_0) + (1 - m)\delta(q - 1), \quad (13.48)$$

此时 (m) 也可解释为概率 (参见第 9 章) .

13.4 理论的进一步发展

寻找 Ising 感知机的解通常非常困难 [10, 17, 18], 但增强消息传递算法却能把二元感知机求解到 $\alpha \sim 0.7$ [1], 二者看似矛盾. Huang 与 Kabashima 把原用于球形自旋玻璃的 Franz–Parisi 框架 [19] 推广到神经网络学习, 揭示了计算困难的来源: 任意有限 α 下, 权重空间中都会出现孤立解, 任意两解之间的典型距离随 α 迅速增大 [2].

基本思路是先在温度 T 选择平衡构型 $\mathbf{J}$, 再约束它与另一温度 T' 下平衡构型 $\mathbf{w}$ 的重叠, 由此得到受限自由能 [19]

$$F(T, T', x) = \overline{\frac{1}{Z(T)} \sum_{\mathbf{J}} e^{-\beta E(\mathbf{J})} \ln \sum_{\mathbf{w}} e^{-\beta' E(\mathbf{w}) + x \mathbf{J} \cdot \mathbf{w}}}. \quad (13.49)$$

横线表示模式分布的淬火平均, 外层还对 $e^{-\beta E(\mathbf{J})} / Z(T)$ 分布平均; β, β' 是逆温. 聚焦基态时, 框架的副本表示为

$$F(x) = \lim_{n \rightarrow 0} \lim_{m \rightarrow 0} \frac{\partial}{\partial m} \overline{\sum_{\{\mathbf{J}^a, \mathbf{w}^\gamma\}} \prod_{\mu} \prod_{a, \gamma} \Theta(u_a^\mu) \Theta(v_\gamma^\mu) \exp \left(x \sum_{\gamma, i} J_i^1 w_i^\gamma \right)}, \quad (13.50)$$

其中 $u_a^\mu = N^{-1/2} \sum_i J_i^a \xi_i^\mu$, $v_\gamma^\mu = N^{-1/2} \sum_i w_i^\gamma \xi_i^\mu$, 详细副本计算见原论文 [2]. 令 $f(x) = \lim_{N \rightarrow \infty} F(x)/N$, 通过 Legendre 变换 $V(p) = f(x) - xp$, $df/dx = p$ 得到 Franz–Parisi 势. $V(p)$ 是与固定平衡解的归一化距离为 $(1 - p)/2$ (Hamming 距离除以 N) 处解数增长率 $e^{NV(p)}$ 的熵.

在 $p \rightarrow 1$ (令 $\epsilon = 1 - p \rightarrow 0$) 时, 原书给出 $dV/dp = \alpha C_p \epsilon^{-1/2} + (\ln \epsilon)/2 + C$, 其中 C 有限且 $C_p > 0$. 第一项支配发散, 因此任意有限 $\alpha > 0$ 下, 熵曲线在 $p = 1$ 处具

有负无穷斜率 $dV/dd = -2dV/dp$, 支持熵曲线中凸部的存在, 并确认 Ising 感知机解簇是点状的.

另一方面, 增强消息传递无法到达孤立解. 该启发式方法以随迭代步增大的概率, 逐渐增强或削弱每个突触感受到的局域场 $h_i = \sum_b u_{b \rightarrow i}$, 可能会搜索权重空间中次主导的稠密区域. 大偏差分析把这一假设写为 [3, 20]

$$F(d, y) = -\frac{1}{Ny} \ln \sum_{\tilde{\mathbf{w}}} \overline{I_{\xi}(\tilde{\mathbf{w}}) \mathcal{N}^y(\tilde{\mathbf{w}}, d)}, \quad (13.51)$$

其中 I 约束 $\tilde{\mathbf{w}}$ 是解, $\mathcal{N}(\tilde{\mathbf{w}}, d) = \sum_{\mathbf{w}} I_{\xi}(\mathbf{w}) \delta(\mathbf{w} \cdot \tilde{\mathbf{w}}, N(1 - 2d))$. 局域熵 $S_L(d, y) = N^{-1} \ln \mathcal{N}(\tilde{\mathbf{w}}, d)$ 可由 $S_L = \partial_y [yF(d, y)]$ 得到. 新测度偏爱周围有大量其他解的个体解, 这些解不必是平衡态孤立解; 次主导稠密区域由 $d = 0$ 附近非零的 $S_L(d, y) > 0$ 表征. 此前的解对熵景观对应 $y = 1$ [21], 冻结图景对应 $y \rightarrow 0$ [2].

这种大偏差分析启发了新的熵驱动算法 [20, 22], 表明启发式学习算法偏向高维权重景观中的平坦区域. 尤其是这些平坦区域比狭窄区域具有更好的泛化性能; 但如何度量权重空间的平坦性仍有激烈争论 [23, 24]. 虽然本章只讨论单层感知机, 同样的统计力学技术也可用于具有特定架构拓扑的多层模型, 相关玩具模型见文献 [25, 26, 27]. 下一章将研究任意拓扑多层网络的统计力学分析.

参考文献

- [1] A. Braunstein and R. Zecchina, Phys. Rev. Lett. 96, 030201 (2006).
- [2] H. Huang and Y. Kabashima, Phys. Rev. E 90, 052813 (2014).
- [3] C. Baldassi et al., Phys. Rev. Lett. 115, 128101 (2015).
- [4] F. Rosenblatt, Psychol. Rev. 65, 386 (1958).
- [5] E. Gardner, Europhys. Lett. 4, 481 (1987).
- [6] E. Gardner, J. Phys. A 21, 257 (1988).
- [7] E. Gardner and B. Derrida, J. Phys. A 22, 1983 (1989).
- [8] W. Krauth and M. Mézard, J. Phys. 50, 3057 (1989).
- [9] A. L. Blum and R. L. Rivest, Neural Netw. 5, 117 (1992).
- [10] H. Horner, Z. Phys. B 86, 291 (1992).
- [11] A. Engel and C. V. den Broeck, *Statistical Mechanics of Learning*, Cambridge University Press (2001).
- [12] G. Gyorgyi, Phys. Rev. A 41, 7097 (1990).
- [13] H. Sompolinsky, N. Tishby, and H. S. Seung, Phys. Rev. Lett. 65, 1683 (1990).
- [14] T. Uezu and K. Nokura, Prog. Theor. Phys. 95, 273 (1996).
- [15] M. Mézard, G. Parisi, and M. A. Virasoro, *Spin Glass Theory and Beyond*, World Scientific (1987).
- [16] M. Mézard and A. Montanari, *Information, Physics, and Computation*, Oxford University Press (2009).
- [17] H. Huang and H. Zhou, J. Stat. Mech. 2010, P08014 (2010).
- [18] H. Huang and H. Zhou, EPL 96, 58003 (2011).
- [19] S. Franz and G. Parisi, J. Phys. I 5, 1401 (1995).
- [20] C. Baldassi et al., J. Stat. Mech. 2016, 023301 (2016).
- [21] H. Huang, K. Y. M. Wong, and Y. Kabashima, J. Phys. A 46, 375002 (2013).
- [22] P. Chaudhari et al., J. Stat. Mech. 2019, 124018 (2019).
- [23] N. S. Keskar et al., ICLR (2017), arXiv:1609.04836.

- [24] L. Dinh et al., ICML (2017), arXiv:1703.04933.
- [25] E. Barkai, D. Hansel, and I. Kanter, Phys. Rev. Lett. 65, 2312 (1990).
- [26] E. Barkai and I. Kanter, Europhys. Lett. 14, 107 (1991).
- [27] E. Barkai, D. Hansel, and H. Sompolinsky, Phys. Rev. A 45, 4146 (1992).

多层感知机的平均场模型

深度学习已成为图像分类和语音识别等领域的强大工具 [1, 2], 多层深度网络也已被证明是普适逼近器 [3]. 然而, 与其成就相比, 深度网络的机制仍难以理解. 冗余性是深度神经网络的重要特征: 移除层间连接时网络仍很稳健 [4]; 换言之, 只有删去超过阈值的大量连接后, 泛化能力才显著变化.

本章先在多层感知机上引入随机活跃路径 (random active path, RAP) 模型研究冗余性 [5]. 路径随机激活, 路径上的权重受相应输入约束, 自然产生一个 p -权重玻尔兹曼模型. 平均场分析揭示出删除扰动的临界值: 它把泛化较差、对扰动不稳健的顺磁相与自旋玻尔兹曼相分开. RAP 模型仍依赖便于理论处理的假设, 有待后续改进. 本章还介绍离散权重多层感知机的平均场训练算法, 以及用系综反向传播理解深度网络的信用分配问题.

14.1 随机活跃路径模型

从统计物理角度, 我们考察深度网络的统计性质如何随突触删除扰动改变. 为作定性回答, 在具有二元突触的多层感知机上提出 RAP 模型.

考虑图 14.1 的四层感知机. 第 $l = 0, 1, 2, 3$ 层有 n_l 个单元; 输入 $\mathbf{v}$ 是分量 $v_i = \pm 1$ 的 n_0 维向量, 二元权重矩阵 W^l 的元素 $w_{ij}^l = \pm 1$, 指定第 $l-1$ 与第 l 层的连接. 非线性函数取 ReLU, 即 $f(u_i) = \max(0, u_i)$. 一般 L 层网络的输出为

$$y = f^{L-1}(W^{L-1} f^{L-2}(W^{L-2} \dots f^1(W^1 \mathbf{v}))). \quad (14.1)$$

本例 $L = 4$. 活跃路径是从一个输入单元通向输出、最终对输出值有贡献的路径. 它须满足两个条件: 因采用 ReLU, 沿途所有单元的激活值均为正; 路径上的每条连接均存在, 而任一突触会以稀释概率被删除. 于是输出可重写为

$$y = \sum_{a=1}^{\Psi} v_a \prod_{k=1}^{L-1} W_{ak}, \quad (14.2)$$

其中 Ψ 是活跃路径总数, v_a 是第 a 条路径的输入节点, W_{ak} 是该路径中属于 W^k 的矩阵元.

实际任务中路径是否活跃还依赖输入驱动的逐层表征. 为简化, 模型假设每条路径的激活独立于输入, 第 l 层单元以可从实际训练估计的概率 ξ_l 独立激活. Hamiltonian 为

$$H(\mathbf{W}) = - \sum_{a=1}^{n^3} A_a v_a \prod_{i \in \partial a} W_i, \quad (14.3)$$

除末层外各层单元数均取 n . $A_a = 1$ 表示路径激活, $A_a = 0$ 表示静默, 且 $P(A_a = 1) = \prod_l \xi_l (1 - p_l)$, p_l 是稀释概率.




图 14.1: RAP 模型所考虑的多层感知机结构；输出单元采用恒等传递函数.

平衡统计物理系统倾向于较低能量，实际深度网络则倾向于较低训练损失. 为建立直观联系，设真实标签 $Y_t = \pm\Omega$ ($\Omega > 0$) 且 Ω 是网络最大输出，并令 $P(Y_t = \pm\Omega) = 1/2$ 、 $P(v_a = \pm 1) = 1/2$. 把 $\text{sgn}(Y_t)$ 吸收到输入后，模型统计不变，Hamiltonian 与绝对误差损失分别为

$$H = -\text{sgn}(Y_t)y, \quad (14.4a)$$

$$C = |Y_t - y|. \quad (14.4b)$$

容易验证，最小化目标与实际输出间的损失等价于寻找 RAP Hamiltonian 的最小值.

14.1.1 腔方法的结果

令权重构型服从 Boltzmann 分布 $P(\mathbf{W}) = e^{-\beta H(\mathbf{W})}/Z$. 腔近似给出自洽消息传递方程

$$\begin{aligned} m_{i \rightarrow a} &= \tanh \left(\sum_{b \in \partial i \setminus a} u_{b \rightarrow i} \right), \\ u_{b \rightarrow i} &= \tanh^{-1} \left[\tanh(\beta v_b) \prod_{j \in \partial b \setminus i} m_{j \rightarrow b} \right]. \end{aligned} \quad (14.5)$$

它与第二章标准方程相似，但有两点关键区别. 第一，路径权重受输入约束： $v_a = +1$ 表示铁磁相互作用， $v_a = -1$ 表示反铁磁相互作用，因而可构造图 14.2 的因子图. 第二，除非所有路径都激活，构型 $\mathbf{W}$ 只是全部权重 $\{W^l\}$ 的子集. 递归求解后，迭代收敛到固定点 $\{m_{i \rightarrow a}, u_{b \rightarrow i}\}$ ，对应 Bethe 自由能的局域或全局极小值（参见第三章），由此可求磁化与熵等统计性质.

为表征相变，定义序参量 $Q = N_w^{-1} \sum_i m_i^2$ ，其中 N_w 是总权重数. 高 Q 表示权重推断有明显偏置，即发生有效学习. 图 14.3 表明，第二层稀释概率 p_1 增大时， Q 先缓慢降低，再在阈值处陡降；该临界值把泛化较差的顺磁区与泛化较好的自旋玻璃区分开. 熵表示候选权重构型数，并随 p_1 增大而增加，说明网络约束减弱；熵在同一临界点有小幅跃变，显示一阶相变. 故删除扰动增大最终会触发向不期望顺磁区的一阶转变.

14.1.2 无限深度分析

现代深度网络可有数千层，因此要问 RAP 模型是否存在无限深度极限、联合能级分布是否因子化，以及降温时能否识别冻结相 [6]. 采用与第七章相似的方法，将 Hamiltonian 写为

$$H(\mathbf{W}) = - \sum_{a=1}^{n^p} \tilde{A}_a \prod_{i \in \partial a} W_i, \quad p = L - 1, \quad \tilde{A}_a = A_a v_a, \quad (14.6)$$




图 14.2: RAP 模型因子图示意. 左: 有两条路径激活的四层感知机. 右: 相应因子图, 圆形变量节点为待估权重, 方形约束节点为活跃路径; 边强度由输入指定.




图 14.3: Q 与熵随 p_1 变化. 数值示意取 $\xi_1 = 0.5, \xi_2 = 0.1, p_2 = p_3 = 0$; $p_1 = 0.9$ 处 Q 陡降且熵有间隙 (虚线), 表明一阶转变. 图据文献 [5] 改绘.

其分布为

$$\begin{aligned}
P(\tilde{A}_a = 0) &= 1 - \prod_l \xi_l(1 - p_l), \\
P(\tilde{A}_a = +1) &= \frac{1}{2} \prod_l \xi_l(1 - p_l), \\
P(\tilde{A}_a = -1) &= \frac{1}{2} \prod_l \xi_l(1 - p_l).
\end{aligned} \tag{14.7}$$

记 $P_0 = P(\tilde{A}_a = 0)$. $N_s = 2^{N_w}$ 个能级的联合分布为

$$\begin{aligned}
P(E^1, \dots, E^{N_s}) &= \left\langle \prod_{\alpha=1}^{N_s} \delta[E^\alpha - H(\mathbf{W}^\alpha)] \right\rangle_{\tilde{A}} \\
&= \prod_{\alpha=1}^{N_s} \int \frac{d\hat{E}^\alpha}{2\pi} e^{i\hat{E}^\alpha E^\alpha} \left\langle e^{-i\sum_{\alpha} \hat{E}^\alpha H(\mathbf{W}^\alpha)} \right\rangle_{\tilde{A}}.
\end{aligned} \tag{14.8}$$

定义无序平均部分 $\mathcal{A}$, 有

$$\mathcal{A} = \prod_{a=1}^{n^p} \left[P_0 + \sum_{\tilde{A}_a = \pm 1} P(\tilde{A}_a) \exp \left(i\tilde{A}_a \sum_{\alpha=1}^{N_s} \hat{E}^\alpha \prod_{i \in \partial a} W_i^\alpha \right) \right]. \tag{14.9}$$

对 $\sigma = \pm 1$ 使用 $e^{a\sigma} = \cosh a(1 + \sigma \tanh a)$,

$$\mathcal{A} = \prod_{a=1}^{n^p} \left[P_0 + \sum_{\tilde{A}_a = \pm 1} P(\tilde{A}_a) \prod_{\alpha=1}^{N_s} \cosh(i\hat{E}^\alpha) \left(1 + \tilde{A}_a \prod_{i \in \partial a} W_i^\alpha \tanh(i\hat{E}^\alpha) \right) \right]. \tag{14.10}$$

作规范变换 $\tilde{A}_a \rightarrow \tilde{A}_a \prod_{i \in \partial a} W_i^\gamma$, 得到

$$\mathcal{A} = \prod_{a=1}^{n^p} \left\{ P_0 + \frac{1 - P_0}{2} \prod_{\alpha} \cosh(i\hat{E}^\alpha) \left[\prod_{\alpha} \left(1 + \tanh(i\hat{E}^\alpha) \prod_{i \in \partial a} W_i^\gamma W_i^\alpha \right) + (\tanh \rightarrow -\tanh) \right] \right\}. \tag{14.11}$$

用平均重叠 $W_i^\gamma W_i^\alpha \rightarrow q^{\gamma\alpha}$ 取代热涨落, 则路径乘积约为 $(q^{\gamma\alpha})^p$, 大 p 时可忽略. 于是

$$\mathcal{A} \simeq \exp \left\{ -n^p \left[\prod_l \xi_l(1 - p_l) \right] \left[1 - \prod_{\alpha=1}^{N_s} \cosh(i\hat{E}^\alpha) \right] \right\}. \tag{14.12}$$

因此联合能级分布为

$$P(E^1, \dots, E^{N_s}) = \prod_{\alpha=1}^{N_s} \int \frac{d\hat{E}^\alpha}{2\pi} \exp \left[i \sum_{\alpha} \hat{E}^\alpha E^\alpha + n^p \prod_l \xi_l(1 - p_l) \left(\prod_{\alpha} \cosh(i\hat{E}^\alpha) - 1 \right) \right]. \tag{14.13}$$

最后讨论小共轭能量极限. 取 $\prod_{\alpha} \cosh(i\hat{E}^{\alpha}) \simeq 1 - \sum_{\alpha} (\hat{E}^{\alpha})^2/2$, 得到

$$\begin{aligned} P(E^1, \dots, E^{N_s}) &= \prod_{\alpha=1}^{N_s} \int \frac{d\hat{E}^{\alpha}}{2\pi} \exp \left[i \sum_{\alpha} \hat{E}^{\alpha} E^{\alpha} - \frac{n^p \prod_l \xi_l (1 - p_l)}{2} \sum_{\alpha} (\hat{E}^{\alpha})^2 \right] \\ &= \prod_{\alpha=1}^{N_s} \frac{1}{\sqrt{2\pi n^p \prod_l \xi_l (1 - p_l)}} \exp \left[-\frac{(E^{\alpha})^2}{2n^p \prod_l \xi_l (1 - p_l)} \right]. \end{aligned} \quad (14.14)$$

在这一极限, 各能级成为独立随机变量; 单个能级服从零均值 Gaussian 分布, 涨落尺度为 $[n^p \prod_l \xi_l (1 - p_l)]^{1/2}$, 括号内正是活跃路径数. 但小共轭能量极限的物理意义尚不清楚, 不能据此断言一般 RAP 模型能级都独立; 无限深度时也不排除非平凡能级结构. 因此仍需系统研究, 包括在实际训练中确认上述一阶转变.

14.2 平均场训练算法

用平均场方法训练二元突触深度监督网络最早见文献 [7]. 设每个权重 w_{ij}^l 从由外场 θ_{ij}^l 参数化的 Bernoulli 分布采样:

$$P(w_{ij}^l) = \sigma(\theta_{ij}^l) \delta_{w_{ij}^l, 1} + [1 - \sigma(\theta_{ij}^l)] \delta_{w_{ij}^l, -1}, \quad (14.15)$$

其均值 $\mu_{ij}^l = 2\sigma(\theta_{ij}^l) - 1$, 方差 $(\sigma_{ij}^l)^2 = -4\sigma^2(\theta_{ij}^l) + 4\sigma(\theta_{ij}^l)$, 其中 $\sigma(x)$ 是 sigmoid 函数. 由中心极限定理, 前馈变换可重参数化为

$$z_j^l = m_j^l + v_j^l \epsilon_j^l, \quad (14.16a)$$

$$a_j^l = \frac{1}{\sqrt{N_{l-1}}} \text{ReLU}(z_j^l), \quad (14.16b)$$

其中 ϵ_j^l 为标准 Gaussian 变量, $m_j^l = \sum_i \mu_{ij}^l a_i^{l-1}$, $(v_j^l)^2 = \sum_i (\sigma_{ij}^l)^2 (a_i^{l-1})^2$.

误差反向传播时, 要计算损失 $\mathcal{L}$ (如分类交叉熵) 关于外场的梯度:

$$\frac{\partial \mathcal{L}}{\partial \theta_{ij}^l} = \frac{\partial \mathcal{L}}{\partial z_j^l} \left(\frac{\partial m_j^l}{\partial \theta_{ij}^l} + \epsilon_j^l \frac{\partial v_j^l}{\partial \theta_{ij}^l} \right). \quad (14.17)$$

定义 $\Delta_j^l = \partial \mathcal{L} / \partial z_j^l$. 顶层有 $\Delta_j^L = y_j^L - \hat{y}_j^L$, 其中 $y_j^L = e^{z_j^L} / \sum_i e^{z_i^L}$, $\hat{y}^L$ 是 one-hot 标签. 由较高层的 Δ_k^{l+1} 递推,

$$\Delta_j^l = \sum_k \Delta_k^{l+1} f'(z_j^l) \left[\mu_{jk}^{l+1} + \epsilon_k^{l+1} \frac{(\sigma_{jk}^{l+1})^2 a_j^l}{v_k^{l+1}} \right]. \quad (14.18)$$

最后,

$$\frac{\partial m_j^l}{\partial \theta_{ij}^l} = 2a_i^{l-1} \sigma'(\theta_{ij}^l), \quad (14.19a)$$

$$\frac{\partial v_j^l}{\partial \theta_{ij}^l} = -\frac{2(a_i^{l-1})^2 \mu_{ij}^l \sigma'(\theta_{ij}^l)}{v_j^l}. \quad (14.19b)$$

在同一小批量梯度下降中, ϵ 被采样后在前向和反向计算中均保持淬火. 学习终止后, 可从由外场参数化的 Bernoulli 分布采样, 构造二元权重的有效网络.

14.3 尖峰-平板模型

尽管深度学习成绩显著，我们对黑箱机制仍知之甚少，例如学习后每个网络参数应分得多少信用. 传统反向传播 [8] 只给出参数点估计，无法捕获噪声感知输入导致的决策不确定性. 相反，从完成任务的候选网络系统出发，文献 [9] 提出尖峰-平板 (spike and slab, SaS) 模型学习信用分配，连接组分微观相互作用与宏观行为，进而识别把感知输入中的信息因素和干扰因素连接到输出行为的关键参数.

14.3.1 系统视角

考虑 L 层前馈网络，其中除输入和输出层外有 $L - 2$ 个隐藏层. 方法也易于推广到 CNN 等架构，网络深度可任意大. 第 l 层宽度记为 N_l ，分类任务中 N_1 与 N_L 分别由输入图像像素数和输出类别数确定. 权重 w_{ij}^l 连接第 l 层神经元 i 与第 $l + 1$ 层神经元 j . 预激活 $z_j^{l+1} = N_l^{-1/2} \sum_i w_{ij}^l h_i^l$ ，缩放因子保证加权和依赖上游层宽度. 隐藏层用 ReLU，输出层用 softmax $h_j^L = e^{z_j^L} / \sum_i e^{z_i^L}$. 目标标签 $\hat{\mathbf{h}}$ 为 one-hot 形式，交叉熵 $C = -\sum_i \hat{h}_i^L \ln h_i^L$. 用 T 个训练数据调整全部连接至满意精度，并用 V 个未见数据测试泛化.

标准反向传播单次运行只得到一组连接权重点估计. 这里假设在给定宽度和深度下，存在完成任务的随机神经网络系统，它可能仅占整个模型空间很小一部分. 用 SaS 分布描述权重 (图 14.4):

$$P(w_{ij}^l) = \pi_{ij}^l \delta(w_{ij}^l) + (1 - \pi_{ij}^l) \mathcal{N}(w_{ij}^l | m_{ij}^l, \Xi_{ij}^l). \quad (14.20)$$

尖峰在零点具有概率质量；平板是在连续支撑上均值 m_{ij}^l 、方差 Ξ_{ij}^l 的 Gaussian 分布. 物理上，尖峰关联网络压缩，平板关联决策不确定性 [9].




图 14.4: 学习信用分配示意. 含两个隐藏层的四层网络识别手写数字 0, softmax 输出给出分类概率. 每条连接由 SaS 分布指定; 尖峰表示连接缺失概率, 平板表示权重的 Gaussian 分布. 强连接绘出不同均值和方差的平板, 弱连接的尖峰概率接近 1, 其平板为简洁起见未画出. 图改编自文献 [9].

14.3.2 训练方程

对所有层学习超参数 $\theta_{ij}^l = (\pi_{ij}^l, m_{ij}^l, \Xi_{ij}^l)$. 权重一、二阶矩为

$$\mu_{ij}^l \equiv \mathbb{E}[w_{ij}^l] = m_{ij}^l(1 - \pi_{ij}^l), \quad (14.21a)$$

$$\varrho_{ij}^l \equiv \mathbb{E}[(w_{ij}^l)^2] = (1 - \pi_{ij}^l)[\Xi_{ij}^l + (m_{ij}^l)^2]. \quad (14.21b)$$

宽层极限下, 中心极限定理表明预激活服从均值 G_i^l 、方差 $(\Delta_i^l)^2$ 的 Gaussian 分布:

$$G_i^l = \frac{1}{\sqrt{N_{l-1}}} \sum_k \mu_{ki}^{l-1} h_k^{l-1}, \quad (14.22a)$$

$$(\Delta_i^l)^2 = \frac{1}{N_{l-1}} \sum_k [\varrho_{ki}^{l-1} - (\mu_{ki}^{l-1})^2] (h_k^{l-1})^2. \quad (14.22b)$$

据此重参数化:

$$z_i^l = G_i^l + \epsilon_i^l \Delta_i^l, \quad (14.23a)$$

$$h_i^l = f(z_i^l). \quad (14.23b)$$

$l < L$ 时 f 为 ReLU, $l = L$ 时为 softmax; 每层每个分量随机产生标准 Gaussian 变量 ϵ_i^l , 在单个小批量的前馈与反向计算中取同一淬火值.

以梯度下降最小化目标函数:

$$\Delta \theta_{ki}^l = -\eta K_i^{l+1} \frac{\partial z_i^{l+1}}{\partial \theta_{ki}^l}, \quad K_i^{l+1} \equiv \frac{\partial C}{\partial z_i^{l+1}}, \quad (14.24)$$

其中 η 是学习率, 梯度在训练数据划分成的小批量上估计. 由式 (14.23) 得

$$\frac{\partial z_i^{l+1}}{\partial m_{ki}^l} = \frac{(1 - \pi_{ki}^l) h_k^l}{\sqrt{N_l}} + \frac{\mu_{ki}^l \pi_{ki}^l (h_k^l)^2 \epsilon_i^{l+1}}{N_l \Delta_i^{l+1}}, \quad (14.25a)$$

$$\frac{\partial z_i^{l+1}}{\partial \pi_{ki}^l} = -\frac{m_{ki}^l h_k^l}{\sqrt{N_l}} - \frac{[(2\pi_{ki}^l - 1)(m_{ki}^l)^2 + \Xi_{ki}^l] (h_k^l)^2 \epsilon_i^{l+1}}{2N_l \Delta_i^{l+1}}, \quad (14.25b)$$

$$\frac{\partial z_i^{l+1}}{\partial \Xi_{ki}^l} = \frac{(1 - \pi_{ki}^l) (h_k^l)^2 \epsilon_i^{l+1}}{2N_l \Delta_i^{l+1}}. \quad (14.25c)$$

这些导数度量预激活对超参数变化的敏感性. 输出层 $K_i^L = h_i^L - \hat{h}_i^L$; 其余层由链式法则得到

$$K_i^l = \delta_i^l f'(z_i^l), \quad (14.26a)$$

$$\delta_i^l = \sum_k K_k^{l+1} \frac{\partial z_k^{l+1}}{\partial h_i^l}. \quad (14.26b)$$

式 (14.26b) 清楚显示梯度信号如何从输出层流向任意中间层, 而

$$\frac{\partial z_k^{l+1}}{\partial h_i^l} = \frac{\mu_{ik}^l}{\sqrt{N_l}} + \frac{[\varrho_{ik}^l - (\mu_{ik}^l)^2] h_i^l \epsilon_k^{l+1}}{N_l \Delta_k^{l+1}}. \quad (14.27)$$

由这些平均场方程可更新模型超参数，SaS 模型因而自然捕获假设空间涨落，与标准反向传播显著不同 [8, 10]. 若强制 $\pi = 0, \Xi = 0$, m 就是一组单一权重构型，训练立即恢复标准反向传播. 因此该协议是权重分布层面的广义反向传播 (gBP). 模型能把确定部分 ($\pi = 0, 1$) 与不确定部分 ($\pi \in (0, 1)$ 且 $\Xi \neq 0, m \neq 0$) 分开；后者可能捕获与任务无关的感知干扰.gBP 得到 U 形 π 分布、L 形 Ξ 分布，以及位于网络中央的模型熵峰，符合“编码–再编码–解码”范式. 尤其是 VIP 权重 ($\pi = 0, \Xi = 0$) 对最终决策行为至关重要，详情见文献 [9].

参考文献

- [1] J. Schmidhuber, Neural Netw. 61, 85 (2015).
- [2] Y. LeCun, Y. Bengio, and G. Hinton, Nature 521, 436 (2015).
- [3] K. Hornik, Neural Netw. 4, 251 (1991).
- [4] Y. LeCun, J. S. Denker, and S. A. Solla, in *Advances in Neural Information Processing Systems 2*, pp. 598–605 (1989).
- [5] H. Huang and A. Goudarzi, Phys. Rev. E 98, 042311 (2018).
- [6] B. Derrida, Phys. Rev. B 24, 2613 (1981).
- [7] O. Shayer, D. Levi, and E. Fetaya, ICLR (2018).
- [8] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, Nature 323, 533 (1986).
- [9] C. Li and H. Huang, Phys. Rev. Lett. 125, 178301 (2020).
- [10] L. Bottou, F. E. Curtis, and J. Nocedal, SIAM Rev. 60, 223 (2018).

降维的平均场理论

长期以来，人们认为大脑感觉皮层通过无监督学习逐层形成更好的感觉表征，不借助标签或奖励便提取数据内禀特征。人工智能与神经科学中的感觉输入在物理上都是高维数据；沿信息层级（如灵长类腹侧视觉通路）产生更抽象表征，本质上是高维数据的非线性降维。然而经验结果并未使深度网络中的层级计算变得透明。本章介绍用平均场理论分析跨层表征降维的框架 [1, 2]。

15.1 平均场模型

考虑图 15.1 的多层前馈网络。隐藏层数定义为深度，网络可任意深；每层单元数定义为宽度，简化起见均取 N 。输入为 $\mathbf{v}$ ，各层表征为 $(\mathbf{h}^1, \dots, \mathbf{h}^d)$ 。令 $\tilde{a}_i^l = \sum_j w_{ij}^l h_j^{l-1}$ ， $h_i^l = \phi(\tilde{a}_i^l + b_i^l)$ ，并取 $\phi(x) = \tanh x$ 。连接第 $l-1$ 与第 l 层的权重矩阵为 w^l ，偏置为 b^l 。为便于解析，假设 $w_{ij}^l \sim \mathcal{N}(0, g/N)$ ， $b_i^l \sim \mathcal{N}(0, \sigma_b)$ ，其中 g 与 σ_b 分别表征权重和偏置强度。




图 15.1: 深度网络示意. 三隐藏层前馈网络的输入为 $\mathbf{v}$ ，各层内部表征为 $(\mathbf{h}^1, \mathbf{h}^2, \mathbf{h}^3)$ ，每层含 N 个单元。

输入点云来自 N 维零均值多元 Gaussian 分布，协方差满足 $\langle v_i v_j \rangle = r_{ij} / \sqrt{N}$ ($i \neq j$, r_{ij} 在 $[-\rho, \rho]$ 均匀分布) 和 $\langle v_i^2 \rangle = 1$ 。定义去均值预激活 $a_i^l = \sum_j w_{ij}^l (h_j^{l-1} - \langle h_j^{l-1} \rangle)$ ，其

均值为零. 协方差

$$\begin{aligned}\Delta_{ij}^l &= \langle a_i^l a_j^l \rangle = \sum_{km} w_{ik}^l w_{jm}^l (\langle h_k^{l-1} h_m^{l-1} \rangle - \langle h_k^{l-1} \rangle \langle h_m^{l-1} \rangle) \\ &= [w^l C^{l-1} (w^l)^\top]_{ij}.\end{aligned}\quad (15.1)$$

记 $m_i^l = \langle h_i^l \rangle$. 大 N 时中心极限定理给出

$$m_i^l = \int Dt \phi \left(\sqrt{\Delta_{ii}^l} t + [w^l \mathbf{m}^{l-1}]_i + b_i^l \right). \quad (15.2)$$

活动协方差为

$$C_{ij}^l = \langle h_i^l h_j^l \rangle - m_i^l m_j^l. \quad (15.3)$$

将两个相关的预激活用独立标准 Gaussian 变量 x, y 参数化:

$$a_i^l = \sqrt{\Delta_{ii}^l} x, \quad (15.4a)$$

$$a_j^l = \sqrt{\Delta_{jj}^l} (\psi x + \sqrt{1 - \psi^2} y), \quad \psi = \frac{\Delta_{ij}^l}{\sqrt{\Delta_{ii}^l \Delta_{jj}^l}}. \quad (15.4b)$$

于是

$$C_{ij}^l = \int Dx Dy \phi(\sqrt{\Delta_{ii}^l} x + z_i^l) \phi[\sqrt{\Delta_{jj}^l} (\psi x + \sqrt{1 - \psi^2} y) + z_j^l] - m_i^l m_j^l, \quad (15.5)$$

其中 $z_i^l = b_i^l + [w^l \mathbf{m}^{l-1}]_i$.

热力学极限下, $i \neq j$ 时 $C_{ij}^l = O(N^{-1/2})$, 从而 $\Delta_{ij}^l = O(N^{-1/2})$, 而 $\Delta_{ii}^l = O(g)$. 围绕 $\Delta_{ij}^l = 0$ 展开式 (15.5),

$$C_{ij}^l \simeq \int Dx Dy \phi(\sqrt{\Delta_{ii}^l} x + z_i^l) \phi'(\sqrt{\Delta_{jj}^l} y + z_j^l) \frac{x \Delta_{ij}^l}{\sqrt{\Delta_{ii}^l}}. \quad (15.6)$$

用 Gaussian 分部积分化简为

$$C_{ij}^l \simeq \int Dx Dy \phi'(\sqrt{\Delta_{ii}^l} x + z_i^l) \phi'(\sqrt{\Delta_{jj}^l} y + z_j^l) \Delta_{ij}^l. \quad (15.7)$$

若再假设耦合强度 g 小, 可对对角方差展开, 只保留一阶:

$$C_{ij}^l \simeq \phi'(z_i^l) \phi'(z_j^l) \Delta_{ij}^l \equiv K_{ij}^l \Delta_{ij}^l. \quad (15.8)$$

式 (15.7) 只需大宽度, 式 (15.8) 还需小耦合.

15.2 线性维数与相关强度

定义第 l 层表征的线性维数 $D^l = (\sum_i \lambda_i)^2 / \sum_i \lambda_i^2$, 其中 $\{\lambda_i\}$ 是 C^l 的本征谱. Cauchy 不等式

$$\frac{1}{N} \left(\sum_{i=1}^N \lambda_i \right)^2 \leq \sum_{i=1}^N \lambda_i^2 \quad (15.9)$$

表明归一化维数 $\mathcal{D}^l = D^l / N \leq 1$. 若本征值全相等, $D^l = N$; 存在非平凡相关时 $D^l < N$. 平均场理论与直接前馈模拟均显示表征维数沿层级逐渐下降 (图 15.2).

定义总体协方差强度 $\Sigma^l = 2[N(N-1)]^{-1} \sum_{i<j} (C_{ij}^l)^2$. 由迹表示,

$$\mathcal{D}^l = \frac{(\text{Tr } C^l)^2}{N \text{Tr}(C^l)^2} = \frac{(N^{-1} \sum_i C_{ii}^l)^2}{2N^{-1} \sum_{i<j} (C_{ij}^l)^2 + N^{-1} \sum_i (C_{ii}^l)^2}. \quad (15.10)$$

因此

$$\Sigma^l = \frac{1}{N-1} \left[\frac{(N^{-1} \sum_i C_{ii}^l)^2}{\mathcal{D}^l} - \frac{1}{N} \sum_i (C_{ii}^l)^2 \right]. \quad (15.11)$$

足够强的连接能在更深层维持弱相关活动, 使信号通过最小 (最大压缩) 表征传播. 增大 σ_b 会显著降低跨层 Σ^l , 却对维数影响很小: 强偏置冻结放电模式, 降低活动相关, 和耦合作用竞争后产生观测维数.




图 15.2: Σ^l 与 $\mathcal{D}^l$ 的数值模拟和理论比较. 输入相关尺度 $\rho/\sqrt{N} = 0.05$; 左图为 10^5 个

样本的前馈模拟, 右图为大 N 理论. 插图取 $\sigma_b = 0.1, N = 100$, 展示相关强度随深度和 g 的变化; 模拟平均十个网络实现.

15.2.1 相关强度的迭代方程

由 $C_{ij}^l \simeq K_{ij}^l \Delta_{ij}^l$,

$$\Sigma^l = \frac{2}{N(N-1)} \sum_{i<j} (K_{ij}^l)^2 (\Delta_{ij}^l)^2. \quad (15.12)$$




图 15.3: 大 N 假设下 Σ^l 与 $\mathcal{D}^l$ 的模拟. 输入相关尺度为 0.05; 插图在 $g = 0.8, N = 100$ 时展示 Σ^l 随深度和 σ_b 的变化, 每组平均十个网络实现.

利用权重统计展开 $(\Delta_{ij}^l)^2$,

$$\Sigma^l \simeq g^2 \Sigma^{l-1} \overline{(K_{ij}^l)^2} + \frac{g^2 \overline{(K_{ij}^l)^2}}{N^2} \sum_i (C_{ii}^{l-1})^2. \quad (15.13)$$

热力学极限下不同权重及不同单元平均预激活的相关可忽略, $\overline{(K_{ij}^l)^2} \simeq [\overline{\phi'(z_i^l)^2}]^2 \equiv (\kappa^l)^2$, 故

$$\Sigma^l \simeq g^2 (\kappa^l)^2 \Sigma^{l-1} + \frac{g^2 (\kappa^l)^2}{N^2} \sum_i (C_{ii}^{l-1})^2. \quad (15.14)$$

第一层满足 $N\Sigma^1 = g^2 (\kappa^1)^2 (N\Sigma^0 + 1)$, 操作点为 $N\Sigma^* = g^2 (\kappa^1)^2 / [1 - g^2 (\kappa^1)^2]$. 其中

$$\kappa^l = \int Du Dt \left[\phi'(\sqrt{\sigma_b}u + \sqrt{gQ^{l-1}}t) \right]^2, \quad (15.15)$$

$$Q^l = \int Du Dt \phi^2(\sqrt{\sigma_b}u + \sqrt{gQ^{l-1}}t), \quad Q^0 = 0. \quad (15.16)$$

若 $\Sigma^0 < \Sigma^*$, 相关增强; 反之减弱. 每层都有依赖该层的操作点, 决定活动相关是增长还是衰减 (图 15.4).

15.2.2 降维机制

归一化输出维数为

$$\mathcal{D}^{l+1} = \frac{(N^{-1} \sum_i C_{ii}^{l+1})^2}{2N^{-1} \sum_{i < j} (C_{ij}^{l+1})^2 + N^{-1} \sum_i (C_{ii}^{l+1})^2}. \quad (15.17)$$




图 15.4: 控制神经相关水平的操作点. 图中 $\Sigma^{0,1}$ (包括临界值) 已乘以网络宽度 N , κ 取第一层值.

为与 $\mathcal{D}^l$ 比较, 把第 $l+1$ 层量改写成第 l 层量. 由 $\Sigma^{l+1} = g^2(\kappa^{l+1})^2\Sigma^l + g^2(\kappa^{l+1})^2N^{-2}\sum_i(C_{ii}^l)^2$, 且

$$C_{ii}^{l+1} = K_{ii}^{l+1}\Delta_{ii}^{l+1} \simeq gK_{ii}^{l+1}k_1^l, \quad k_1^l \equiv \frac{1}{N} \sum_i C_{ii}^l, \quad (15.18)$$

再定义 $k_2^l = N^{-1}\sum_i(C_{ii}^l)^2$, 得到

$$\mathcal{D}^{l+1} = \frac{(k_1^l)^2}{(N-1)\Sigma^l + k_2^l + \frac{\overline{(K_{ii}^{l+1})^2}}{\overline{(K_{ii}^{l+1})^2}}(k_1^l)^2}. \quad (15.19)$$

而

$$\mathcal{D}^l = \frac{(k_1^l)^2}{(N-1)\Sigma^l + k_2^l}. \quad (15.20)$$

式 (15.19) 分母中新增项始终为正, 故严格保证 $\mathcal{D}^{l+1} < \mathcal{D}^l$. 在大 N 极限,

$$\overline{K_{ii}^l} = \int Dt Du [\phi'(\sqrt{\sigma_b}u + \sqrt{gQ^{l-1}}t)]^2, \quad (15.21a)$$

$$Q^{l-1} = \int Du Dt \phi^2(\sqrt{\sigma_b}u + \sqrt{gQ^{l-2}}t), \quad (15.21b)$$

$$\overline{(K_{ii}^l)^2} = \int Dt Du [\phi'(\sqrt{\sigma_b}u + \sqrt{gQ^{l-1}}t)]^4. \quad (15.21c)$$

由 $k_1^l = \langle (h_i^l)^2 \rangle - Q^l$, 递推形式为

$$k_1^l = \int Dx \phi^2(\sqrt{\Delta_{ii}^l}x + b_i^l + [w^l \mathbf{m}^{l-1}]_i) - Q^l, \quad (15.22)$$

$$k_1^l = \int Du Dy \phi^2(\sqrt{gk_1^{l-1} + gQ^{l-1}}y + \sqrt{\sigma_b}u) - Q^l. \quad (15.23)$$

因此正加性项显式为

$$\frac{\overline{(K_{ii}^{l+1})^2}}{(\overline{K_{ii}^{l+1}})^2} (k_1^l)^2 = \frac{\int Dt Du [\phi'(\sqrt{\sigma_b}u + \sqrt{gQ^l}t)]^4}{\{\int Dt Du [\phi'(\sqrt{\sigma_b}u + \sqrt{gQ^l}t)]^2\}^2} \left[\int Du Dy \phi^2(\sqrt{gk_1^{l-1} + gQ^{l-1}}y + \sqrt{\sigma_b}u) - Q^l \right]^2. \quad (15.24)$$

理论和有限尺寸模拟均表明, 该正项随深度增大趋向很小 (图 15.5), 所以深层估计维数近乎常数. 平均场理论由此再现降维与神经去相关的关键特征, 也与神经科学的冗余减少假说 [3] 相容; 这些机制在加入学习等细节后是否稳健仍待研究.




图 15.5: 加性项随网络深度的变化. 理论基于大 N 极限, 模拟在有限系统 $N = 100$ 中进行.

15.3 相关突触下的降维

前述理论假定突触权重独立同分布, 但真实皮层回路同层神经元之间的突触未必理想独立 [4]. 下面用平均场理论研究弱相关突触怎样影响分层表征 [2].

15.3.1 模型设定

考虑 d 个隐藏层、每层 N 个神经元的深度随机网络. w^l 第 i 行是上一层神经元 i 的连接, 即感受野; 只讨论二元权重 ± 1 , 连续权重可类似分析. 令 $z_i^l = g[w^l \mathbf{h}^{l-1}]_i / \sqrt{N} + b_i^l$,

$h_i^l = \tanh z_i^l$. 突触协方差结构 (图 15.6) 为

$$\overline{w_{ij}^l w_{ks}^l} = \delta_{js} q + \delta_{ik} \delta_{js} (1 - q). \quad (15.25)$$

权重均值为零, 偏置服从 $\mathcal{N}(0, \sigma_b)$. 不预设相关水平 q 的缩放, 而由自洽性确定. 输入从零均值多元 Gaussian 分布独立采样, 协方差 $\Lambda = N^{-1} \xi \xi^\top$, 其中 $N \times P$ 矩阵 ξ 的元素均值为零、方差为 σ^2 (本文取 0.5); $\alpha = P/N$ 控制协方差谱密度 (见第 17 章).




图 15.6: 相关突触深度网络. 逐层变换产生内部表征 $\{\mathbf{h}^l\}$; 层上方矩阵指定突触协方差, g 表征权重方差, 对角块表征不同感受野对应突触的相关, q 是相关强度. 图改编自文献 [2].

15.3.2 平均场计算

活动矩的平均场迭代 均值活动满足

$$m_i^l = \left\langle \phi \left(a_i^l + \frac{g}{\sqrt{N}} [w^l \mathbf{m}^{l-1}]_i + b_i^l \right) \right\rangle, \quad (15.26)$$

其中 $a_i^l = g N^{-1/2} \sum_j w_{ij}^l (h_j^{l-1} - m_j^{l-1})$, $\langle a_i^l \rangle = 0$, $\Delta_{ij}^l = g^2 N^{-1} [w^l C^{l-1} (w^l)^\top]_{ij}$. 中心极限定理给出

$$m_i^l = \int Dt \phi \left(\sqrt{\Delta_{ii}^l} t + \frac{g}{\sqrt{N}} \sum_j w_{ij}^l m_j^{l-1} + b_i^l \right). \quad (15.27)$$

活动协方差为

$$C_{ij}^l = \int Dx Dy \phi \left(\sqrt{\Delta_{ii}^l} x + z_{0i}^l \right) \phi \left[\sqrt{\Delta_{jj}^l} (\psi x + \sqrt{1 - \psi^2} y) + z_{0j}^l \right] - m_i^l m_j^l, \quad (15.28)$$

其中 $z_{0i}^l = b_i^l + gN^{-1/2}[w^l \mathbf{m}^{l-1}]_i$, $\psi = \Delta_{ij}^l / \sqrt{\Delta_{ii}^l \Delta_{jj}^l}$. 线性维数为

$$D^l = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2} = \frac{(\text{Tr } C^l)^2}{\text{Tr}(C^l)^2} = \frac{(\sum_i C_{ii}^l)^2}{\sum_{ij} (C_{ij}^l)^2}. \quad (15.29)$$

再定义 $K_1^l = N^{-1} \sum_i C_{ii}^l$, $K_2^l = N^{-1} \sum_i (C_{ii}^l)^2$, $\Sigma^l = 2N^{-2} \sum_{i < j} (C_{ij}^l)^2$, 则

$$\tilde{D}^l = \frac{D^l}{N} = \frac{(K_1^l)^2}{N\Sigma^l + K_2^l}. \quad (15.30)$$

两点相关的展开 平均场极限下, $i \neq j$ 时 $C_{ij}^l = O(N^{-1/2})$, 故 $\Delta_{ij}^l = O(g^2 N^{-1/2})$ 很小. 对它作 Taylor 展开,

$$\phi[\sqrt{\Delta_{jj}^l}(\psi x + \sqrt{1 - \psi^2} y) + z_{0j}^l] = \phi(\sqrt{\Delta_{jj}^l} y + z_{0j}^l) + \phi'(\sqrt{\Delta_{jj}^l} y + z_{0j}^l) \frac{x \Delta_{ij}^l}{\sqrt{\Delta_{ii}^l}} + O[(\Delta_{ij}^l)^2]. \quad (15.31)$$

因此

$$C_{ij}^l = \int Dx Dy \phi'(\sqrt{\Delta_{ii}^l} x + z_{0i}^l) \phi'(\sqrt{\Delta_{jj}^l} y + z_{0j}^l) \Delta_{ij}^l + O[(\Delta_{ij}^l)^2]. \quad (15.32)$$

将线性系数记为 K_{ij}^l . 小 g 时 $\Delta_{ii}^l \simeq g^2 K_1^{l-1} = O(g^2)$, 再展开得

$$C_{ij}^l \simeq \phi'(z_{0i}^l) \phi'(z_{0j}^l) \Delta_{ij}^l. \quad (15.33)$$

对角协方差为

$$C_{ii}^l = \int Dx \phi^2(\sqrt{\Delta_{ii}^l} x + z_{0i}^l) - \left[\int Dx \phi(\sqrt{\Delta_{ii}^l} x + z_{0i}^l) \right]^2. \quad (15.34)$$

在小 Δ_{ii}^l 下,

$$C_{ii}^l \simeq [\phi'(z_{0i}^l)]^2 \Delta_{ii}^l \equiv K_{ii}^l \Delta_{ii}^l. \quad (15.35)$$

提高预测精度需保留高阶项; 实际把式 (15.32) 取 $i = j$, 由于已纳入 Δ_{ii}^l 的贡献, 即使 g 较大也能较好匹配模拟.

相关强度 Σ^l 的迭代 在大 N 、小 g 极限,

$$K_1^l = \overline{[\phi'(z_{0i}^l)]^2} \Delta_{ii}^l \simeq \overline{[\phi'(z_{0i}^l)]^2} g^2 K_1^{l-1}. \quad (15.36)$$

这里

$$\Delta_{ii}^l \simeq \frac{g^2}{N} \sum_{kj} w_{ik}^l w_{ij}^l C_{kj}^{l-1} = \frac{g^2}{N} \sum_k C_{kk}^{l-1} = g^2 K_1^{l-1}. \quad (15.37)$$

预激活均值部分由中心极限定理处理：

$$\overline{[\phi'(z_{0i}^l)]^2} = \int Dx [\phi'(x\sqrt{g^2 Q^{l-1}} + \sigma_b)]^2 \equiv K_{ii}^l. \quad (15.38)$$

$Q^l = N^{-1} \sum_i (m_i^l)^2$ 的递推为

$$Q^l = \int Dx \left[\int Dt \phi(\sqrt{g^2 K_1^{l-1}} t + x\sqrt{g^2 Q^{l-1}} + \sigma_b) \right]^2. \quad (15.39)$$

所以

$$K_1^l = g^2 K_{ii}^l K_1^{l-1}. \quad (15.40)$$

不采用小 g 假设时也可递推：

$$K_1^l = \int Dx \phi^2 \left(x\sqrt{g^2 K_1^{l-1}} + \sigma_b + g^2 Q^{l-1} \right) - Q^l. \quad (15.41)$$

对角平方矩满足

$$K_2^l = \frac{1}{N} \sum_i (C_{ii}^l)^2 = (\overline{(K_{ii}^l)^2}) g^4 (K_1^{l-1})^2, \quad (15.42)$$

其中

$$\overline{(K_{ii}^l)^2} = \int Dx [\phi'(x\sqrt{g^2 Q^{l-1}} + \sigma_b)]^4. \quad (15.43)$$

不取小 g 时，

$$K_2^l = \overline{\{\langle \phi^2(f) \rangle_z - \langle \phi(f) \rangle_z^2\}_{u,t}^2}, \quad f = \sqrt{g^2 K_1^{l-1}} z + \sqrt{\sigma_b} u + \sqrt{g^2 Q^{l-1}} t. \quad (15.44)$$

最后推导 Σ^l . 对二元权重，统计平均给出

$$\overline{\left(\sum_{kl} w_{ik} w_{jl} C_{kl} \right)^2} \simeq (1+q^2) \sum_{k \neq l} C_{kl}^2 + (1-q^2) \sum_k C_{kk}^2 + q^2 \left(\sum_k C_{kk} \right)^2. \quad (15.45)$$

从而

$$N \Sigma^{l+1} \simeq \overline{(K_{ij}^{l+1})^2} g^4 [N \Sigma^l + K_2^l + r^2 (K_1^l)^2]. \quad (15.46)$$

物理自洽性唯一确定 $q = r/\sqrt{N}$ ，其中 $r = O(1)$. 线性系数递推为

$$\begin{aligned} \overline{(K_{ij}^{l+1})^2} &= \overline{\left\langle \phi'(\sqrt{g^2 K_1^l} x + \sqrt{g^2 Q^l} z_1 + \sqrt{\sigma_b} u_1) \right\rangle_x^2} \\ &\times \overline{\left\langle \phi'(\sqrt{g^2 K_1^l} y + \sqrt{g^2 Q^l} [\rho z_1 + \sqrt{1-\rho^2} z_2] + \sqrt{\sigma_b} u_2) \right\rangle_y^2}, \end{aligned} \quad (15.47)$$

外平均遍历 z_1, z_2, u_1, u_2 , 且

$$\rho \equiv \frac{\overline{(z_{0i} - b_i)(z_{0j} - b_j)}}{\sqrt{\overline{(z_{0i} - b_i)^2} \overline{(z_{0j} - b_j)^2}}} = q. \quad (15.48)$$

突触相关在信号通过隐藏表征时会增强神经相关. 令 $\Upsilon = g^4 \overline{(K_{ij}^{l+1})^2}$, 乘以 N 后的操作点为

$$\Sigma_l^* = \frac{\Upsilon K_2^l}{1 - \Upsilon} + \frac{\Upsilon r^2 (K_1^l)^2}{1 - \Upsilon}. \quad (15.49)$$

最后一项说明突触相关提高操作点, 也把线性关系的截距提高正量 $\Upsilon r^2 (K_1^l)^2$; 正交权重和相关权重情形的斜率相同 (图 15.7) .




图 15.7: 突触相关如何提高深度网络隐藏表征的神经相关水平 (已乘 N) 及操作点. 双箭头给出输入 Σ^l 低于星号所示操作点时的增强. 图改编自文献 [2].

跨层维数迭代 由 K_1^l, K_2^l, Σ^l 的递推,

$$\tilde{D}^l = \frac{(K_1^l)^2}{N\Sigma^l + K_2^l} = \frac{(K_1^{l-1})^2}{\gamma_1(N\Sigma^{l-1} + K_2^{l-1}) + \gamma_1 r^2 (K_1^{l-1})^2 + \gamma_2 (K_1^{l-1})^2}, \quad (15.50)$$

其中 $\gamma_1 = \overline{K_{ij}^2}/(\overline{K_{ii}})^2$ 、 $\gamma_2 = \overline{K_{ii}^2}/(\overline{K_{ii}})^2$ 、 $r = q\sqrt{N}$. 输出维数受乘性因子 γ_1 与分母最后的正加性项调控. 具体量为

$$\begin{aligned}\overline{K_{ii}} &= \int Dx [\phi'(x\sqrt{g^2Q^{l-1} + \sigma_b})]^2, \\ \overline{K_{ii}^2} &= \int Dy [\phi'(y\sqrt{g^2Q^{l-1} + \sigma_b})]^4, \\ \overline{K_{ij}^2} &= \text{式 (15.47) 的双层 Gaussian 平均}.\end{aligned}\tag{15.51}$$

估计维数的闭式平均场迭代 实际估计可直接使用

$$\Delta_{ij}^l = \frac{g^2}{N} \sum_{kk'} w_{ik}^l C_{kk'}^{l-1} w_{jk'}^l, \tag{15.52}$$

$$m_i^l = \int Dt \phi \left(\sqrt{\Delta_{ii}^l} t + \frac{g}{\sqrt{N}} \sum_{j=1}^N w_{ij}^l m_j^{l-1} + b_i^l \right), \tag{15.53}$$

以及

$$\begin{aligned}C_{ij}^l &= \int Dx Dy \phi \left(\sqrt{\Delta_{ii}^l} x + b_i^l + \frac{g}{\sqrt{N}} \sum_k w_{ik}^l m_k^{l-1} \right) \\ &\times \phi \left[\sqrt{\Delta_{jj}^l} (\psi x + \sqrt{1 - \psi^2} y) + b_j^l + \frac{g}{\sqrt{N}} \sum_{k'} w_{jk'}^l m_{k'}^{l-1} \right] - m_i^l m_j^l.\end{aligned}\tag{15.54}$$

15.3.3 数值结果与理论比较

权重与合成数据的生成 考虑一层输入加四隐藏层的五层全连接网络, 每层 N 个神经元. 初始化后参数在维数估计中保持不变, 结果对许多独立网络实现平均. 二元权重 $w_{ij}^l = \pm 1$ 均值为零, 协方差

$$\overline{w_{ij}^l w_{ks}^l} = \delta_{js} q + \delta_{ik} \delta_{js} (1 - q) = q \delta_{js} (1 - \delta_{ik}) + \delta_{ik} \delta_{js}. \tag{15.55}$$

由于每个感受野内部不相关, 可用二值化 Gaussian (DG) 过程分别生成图 15.8 的各对角块: $w_{ij}^l = \text{sign}(x_{ij}^l)$, 其中

$$\text{sign}(x) = \begin{cases} 1, & x \geq 0, \\ -1, & x < 0, \end{cases} \tag{15.56}$$

而零均值多元 Gaussian 变量 x 的协方差为

$$\overline{x_{ij}^l x_{ks}^l} = \delta_{js} \varrho + \delta_{ik} \delta_{js} (1 - \varrho) = \varrho \delta_{js} (1 - \delta_{ik}) + \delta_{ik} \delta_{js}. \tag{15.57}$$

匹配 DG 过程与预设相关 q ,

$$q = \int Dx Dy \text{sign}(x) \text{sign}(\varrho x + \sqrt{1 - \varrho^2} y) = \frac{2}{\pi} \arcsin \varrho, \tag{15.58}$$

故

$$\varrho = \sin \frac{\pi q}{2}. \quad (15.59)$$

对 $N \times N$ 协方差矩阵 Λ 作 Cholesky 分解 $\Lambda = LL^\top$, 取 $z = L\epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ 即得样本; 偏置独立服从 $\mathcal{N}(0, \sigma_b)$.




图 15.8: 用于生成相关二元权重的 x^l 协方差矩阵示意. 图改编自文献 [2].

结果 理论预测为机器学习中常见的权重与神经去相关启发式技巧提供了原理解释 [6, 7, 8]. 与正交权重相比, 弱突触相关使隐藏表征跨层维数进一步降低 (图 15.9a), 也增强神经相关强度, 且浅层增强更明显 (图 15.9b). 因此弱突触相关加速降维, 同时减缓神经相关强度的衰减.

改变 g 和 σ_b 对降维没有或只有可忽略影响; 权重强度却会提高相关水平, 作用类似突触相关, 增大发放偏置则进一步去相关 (图 15.9c). 输出维数由乘性因子 γ_1 和式 (15.50) 分母中的加性项共同调节 (图 15.9d). γ_1 随深度增长至 1, 在 $q = 0$ 时恒为 1; 加性项始终为正并随深度下降. 因此两项共同使深层的降维逐渐变弱.




图 15.9: 二元权重网络的典型降维行为. 有限尺寸 $N = 200$, 平均十个实例.(a) 不同相关水平 r 的逐层降维, $g = 0.9, \alpha = 2, \sigma_b = 0.1$, 叉号为传播 10^5 个样本的模拟; (b) 不同 r 的逐层去相关, 相关强度已乘 N ; (c) 改变 g, σ_b 时的降维和去相关, $r = 0.5$; (d) $g = 0.4$ 的大 N 行为, 插图显示 γ_1 、加性项及理论与 $N = 200$ 模拟的维数比较. 图改编自文献 [2].

参考文献

- [1] H. Huang, Phys. Rev. E 98, 062313 (2018).
- [2] J. Zhou and H. Huang, Phys. Rev. E 103, 012315 (2021).
- [3] H. Barlow, in *Sensory Communication*, MIT Press, pp. 217–234 (1961).
- [4] K. Harris and G. Shepherd, Nat. Neurosci. 18, 170 (2015).
- [5] J. H. Macke et al., Neural Comput. 21, 397 (2009).
- [6] M. Cogswell et al., ICLR (2016), arXiv:1511.06068.
- [7] P. Rodriguez et al., ICLR (2017), arXiv:1611.01967.
- [8] G. Jin et al., NeurIPS (2020), arXiv:2010.05983.

随机循环神经网络的混沌理论

在计算神经科学中, 分析循环神经网络 (RNN) 有望揭示工作记忆、决策和学习等认知功能背后的动力学计算原理 [1]. 常见做法是模拟由膜电位演化描述的脉冲神经网络: 单个神经元不再由 0 或 1 的单一激活值刻画, 只有膜电位达到阈值才发放脉冲, 随后进入短暂静默期. 发放率模型是脉冲动力学的抽象, 其性质可用统计力学分析. 本章介绍动力学平均场理论, 说明固定点动力学如何转变为混沌, 并以平均场论证解释实验所见的不规则异步皮层活动.

16.1 脉冲模型与发放率模型

神经信息由包括脉冲在内的发放活动表征, 活动模式的时空演化体现信息处理. 神经元激活时产生离散脉冲, 经兴奋或抑制连接提高或降低邻近神经元膜电位. 漏积分发放 (LIF) 方程为 [2]

$$\frac{dV_i(t)}{dt} = -\frac{V_i(t) - V_{\text{rest}}}{\tau_m} + \sum_{jn} J_{ij} \delta(t - t_{jn} - \Delta_{ij}) + J_{\text{ext}} \sum_n \delta(t - \tilde{t}_{in}). \quad (16.1)$$

$V_i(t)$ 是第 i 个神经元膜电位, J_{ij} 是从突触前 j 到突触后 i 的突触效能, 且 $J_{ii} = 0$. 兴奋神经元外向突触为正, 抑制神经元为负. τ_m (如 20 ms) 是膜时间常数; Δ_{ij} 是传输延迟, t_{jn} 是第 j 个神经元第 n 次脉冲时刻. 最后一项是外部刺激; $J_{\text{ext}} = 0$ 时称自发或自主动力学.

更真实的循环突触输入可写成瞬时跳跃和指数衰减过程 [3]:

$$\tau_s \frac{dI_s}{dt} = -I_s(t) + \sum_{jn} J_{ij} \delta(t - t_{jn}), \quad (16.2)$$

其中 τ_s 是突触松弛时间. 式 (16.1) 相当于忽略相对神经元时间常数很短的突触时间常数. 膜电位达到阈值后立即发放并快速降至重置电位, 在不应期 τ_{ref} 内忽略所有输入 (图 16.1). 清醒动物皮层通常表现低频异步不规则活动; LIF 统计分析详见文献 [1].

下面研究更简单的发放率模型; 脉冲动力学在宏观层面能否等价于发放率模型仍有争论 [4]. 用指定时间窗内的发放频率 (或概率) 代替脉冲. N 个神经元由局域电流 $x_i(t)$ 描述, 发放率 $r_i = \tanh x_i$. 省略外部驱动,

$$\frac{dx_i}{dt} = -x_i + \eta_i, \quad \eta_i = \sum_{j=1}^N J_{ij} \phi(x_j), \quad \phi(x) = \tanh x. \quad (16.3)$$

各突触独立取 $J_{ij} \sim \mathcal{N}(0, g^2/N)$, g 表征循环反馈强度; N^{-1} 缩放保证大 N 时加权和为 $O(1)$.




Fig. 16.1: An illustration of cyclic dynamics in a recurrent neural network. (Left) Network sketch.

图 16.1: 循环网络脉冲动力学. 左: 随机连接的兴奋 (E)、抑制 (I) 和外部 Poisson (X) 三个群体. 右: 一个 E 和一个 I 神经元的脉冲序列. 阈值 -52 mV, 重置电位 -70 mV, $\tau_{\text{ref}} = 2$ ms, $\tau_m = 20$ ms, $\tau_s = 10$ ms; $N = 16000$, 其中抑制神经元 4000 个, 稀疏连接概率 $p = 0.1$.

16.2 动力学平均场理论

动力学平均场理论源于发放率动力学生成泛函形式 [5], 1988 年首次用于循环网络 [6]. 这种路径积分方法用于对所有动力学轨迹作无序平均 [7], 最初服务于自旋系统随机动力学 [8, 9, 10, 11].

16.2.1 动力学平均场方程

稳态时, 高维系统可约化为由 Gaussian 噪声驱动的代表性神经元. 驱动力 $\eta_i(t)$ 绕零均值涨落:

$$[\langle \eta_i(t) \rangle]_J = \sum_j [J_{ij} \phi(x_j)]_J \simeq 0. \quad (16.4)$$

方括号是耦合无序平均, 角括号是时间平均, 并采用长时遍历性. 延时相关为

$$[\langle \eta_i(t) \eta_j(t + \tau) \rangle]_J = \delta_{ij} g^2 \langle \phi(x_k(t)) \phi(x_k(t + \tau)) \rangle = \delta_{ij} g^2 C(\tau), \quad (16.5)$$

$$C(\tau) = \langle \phi(x_k(t)) \phi(x_k(t + \tau)) \rangle. \quad (16.6)$$

长时极限下只依赖时间间隔 τ , 即时间平移不变.

对式 (16.3) Fourier 变换,

$$(1 + i\omega) \hat{x}(\omega) = \hat{\eta}(\omega), \quad (16.7)$$

$$(1 - i\omega) \hat{x}(-\omega) = \hat{\eta}(-\omega). \quad (16.8)$$

两式相乘:

$$(1 + \omega^2) \hat{x}(-\omega) \hat{x}(\omega) = \hat{\eta}(\omega) \hat{\eta}(-\omega). \quad (16.9)$$

右侧逆变换给出

$$\frac{1}{2\pi} \int d\omega \hat{\eta}(\omega) \hat{\eta}(-\omega) e^{i\omega\tau} = \langle \eta(t) \eta(t + \tau) \rangle, \quad (16.10)$$

左侧则为

$$\frac{1}{2\pi} \int d\omega (1 + \omega^2) \hat{x}(\omega) \hat{x}(-\omega) e^{i\omega\tau} = \left(1 - \frac{d^2}{d\tau^2}\right) \Delta(\tau), \quad (16.11)$$

其中 $\Delta(\tau) = \langle x_i(t) x_i(t + \tau) \rangle$. 合并得

$$\Delta - \ddot{\Delta} = g^2 C(\tau). \quad (16.12)$$

由中心极限定理, $x(t)$ 近似 Gaussian:

$$\langle x(t) \rangle = \langle x(t + \tau) \rangle = 0, \quad \langle x(t) x(t + \tau) \rangle = \Delta(\tau). \quad (16.13)$$

参数化为

$$x(t) = \alpha y + \beta z, \quad x(t + \tau) = \alpha y' + \beta z, \quad (16.14)$$

其中 $\alpha = \sqrt{\Delta(0) - |\Delta(\tau)|}$, $\beta = \sqrt{|\Delta(\tau)|}$. 于是

$$C(\tau) = \int Dy Dy' Dz \phi(\alpha y + \beta z) \phi(\alpha y' + \beta z) = \int Dz \left[\int Dy \phi(\alpha y + \beta z) \right]^2. \quad (16.15)$$

式 (16.12) 可视为势阱中粒子运动:

$$\ddot{\Delta} = -\frac{\partial V}{\partial \Delta}, \quad (16.16)$$

$$V = -\frac{\Delta^2}{2} + g^2 V_2, \quad \frac{\partial V_2}{\partial \Delta} = C(\tau). \quad (16.17)$$

若 $\Phi'(x) = \phi(x)$, 则

$$V_2 = \int Dz \left[\int Dy \Phi(\alpha y + \beta z) \right]^2. \quad (16.18)$$

可用 Price 定理验证. 最终动力学平均场方程为

$$\begin{aligned} \ddot{\Delta} &= -\frac{\partial V}{\partial \Delta}, \\ V(\Delta) &= -\frac{\Delta^2}{2} + g^2 \int Dz \left[\int Dy \Phi(\sqrt{\Delta(0) - |\Delta|} y + \sqrt{|\Delta|} z) \right]^2. \end{aligned} \quad (16.19)$$

16.2.2 网络动力学区间

式 (16.19) 描述粒子在势 $V(\Delta)$ 中从 $\Delta(0)$ 出发、初速度 $\dot{\Delta}(0) = 0$ 的运动. 物理约束是 $\Delta(0) \geq |\Delta(t)|$ 、 $\Delta(0) > 0$, 且由时间平移不变性, $\Delta(t)$ 是可微偶函数. 总能量守恒: $\dot{\Delta}^2/2 + V[\Delta(t)] = V[\Delta(0)]$. 势的导数为

$$\frac{\partial V}{\partial \Delta} = -\Delta + g^2 \int Dz \left[\int Dy \phi(\sqrt{\Delta(0) - |\Delta|} y + \sqrt{|\Delta|} z) \right]^2, \quad (16.20a)$$

$$\frac{\partial^2 V}{\partial \Delta^2} = -1 + g^2 \int Dz \left[\int Dy \phi'(\sqrt{\Delta(0) - |\Delta|} y + \sqrt{|\Delta|} z) \right]^2. \quad (16.20b)$$

奇传递函数满足 $V'(0) = 0$. 因 $0 < \phi' \leq 1$, 当 $g < 1$ 时 $V'' < 0$, 势严格凹且极大在 $\Delta = 0$; 当 $g > 1$ 时, $V''(0)$ 还依赖 $\Delta(0)$, 势可为单阱或双阱 (图 16.2).

当 $g < 1$ 时, 除违反物理界的轨迹外只剩 $\Delta(t) = \Delta(0) = 0$, 即全静默的平凡固定点. $g > 1$ 且 $\Delta(0)$ 小时, Δ 在 $\pm\Delta(0)$ 间振荡, 对应极限环. 双阱且 $\Delta(0)$ 较大时: 若从阱底出发则为静态解; 稍偏离阱底会绕阱底振荡; 更高能量可跨两阱振荡; 特殊初值满足 $V[\Delta(0)] = V(0)$ 时, $\Delta(\tau)$ 单调衰减并在 $\tau \rightarrow \infty$ 趋零, 这是混沌态. 若 $\Delta(t) \sim \Delta(0)e^{-t/\tau_e}$, 松弛时间 $\tau_e = [-V''(0)]^{-1/2}$.

路径积分鞍点涨落 Hessian 可检验稳定性 [11]: $g < 1$ 的静态解稳定; $g > 1$ 的振荡解不稳定, 唯一稳定的是混沌解. 有限网络可显示振荡活动, 但随 N 增大振荡消失, 混沌转变变尖锐.




图 16.2: 循环发放率网络的动力学区间 [6], 曲线实点表示可能的初始位置: (a) $g < 1$; (b) $g > 1$ 且 $\Delta(0)$ 小; (c) $g > 1$ 且 $\Delta(0)$ 大.

16.3 Lyapunov 指数与混沌

在式 (16.3) 中加入无穷小扰动 $\delta x_i(t)$, 线性化得

$$\frac{dx_i}{dt} + \frac{d\delta x_i}{dt} = -[x_i + \delta x_i] + \sum_j J_{ij}[\phi(x_j) + \phi'(x_j)\delta x_j]. \quad (16.21)$$

与原方程相减,

$$(\partial_t + 1)\delta x_i(t) = \sum_j J_{ij}\phi'(x_j(t))\delta x_j(t). \quad (16.22)$$

时间平移后,

$$(\partial_{t+\tau} + 1)\delta x_k(t + \tau) = \sum_l J_{kl}\phi'(x_l(t + \tau))\delta x_l(t + \tau). \quad (16.23)$$

两式相乘并对 J 平均:

$$(\partial_t + \partial_{t+\tau} + \partial_t \partial_{t+\tau} + 1)\Delta_g(t, \tau) = g^2 C_{\phi'}(\tau) \Delta_g(t, \tau), \quad (16.24)$$

其中 $C_{\phi'} = \langle \phi'(x(t))\phi'(x(t + \tau)) \rangle$, $\Delta_g = \langle \delta x(t)\delta x(t + \tau) \rangle$. 作变量变换 $T = t + (t + \tau)$, $\tau = (t + \tau) - t$, 并用 $g^2 C_{\phi'} = V''[\Delta(\tau)] + 1$, 得

$$[(1 + \partial_T)^2 - \partial_\tau^2] \Delta_g(T, \tau) = \{V''[\Delta(\tau)] + 1\} \Delta_g(T, \tau). \quad (16.25)$$

若 $|\delta x(t)| \sim |\delta x(0)|e^{\lambda t}$, 最大 Lyapunov 指数为

$$\lambda_{\max} = \lim_{t \rightarrow \infty} \frac{1}{2t} \ln \sum_i [\delta x_i(t)]^2 = \lim_{t \rightarrow \infty} \frac{1}{2t} \ln \Delta_g(t, 0), \quad (16.26)$$

取 $\|\delta \mathbf{x}(0)\|^2 = 1$. 令 $\Delta_g(t, \tau) = e^{kt}\psi(\tau)$, 则 $\lambda_{\max} = k/2$, 式 (16.25) 化为一维定态 Schrödinger 方程

$$[-\partial_\tau^2 - V''(\Delta(\tau))] \psi(\tau) = [1 - (1 + k/2)^2] \psi(\tau). \quad (16.27)$$

量子势为 $W(\tau) = -V''$, 能量为 $E = 1 - (1 + k/2)^2$. 本征能 E_n 决定增长率

$$k_n^\pm = 2(-1 \pm \sqrt{1 - E_n}). \quad (16.28)$$

记基态能量为 E_0 ,

$$\lambda_{\max} = -1 + \sqrt{1 - E_0}. \quad (16.29)$$

零固定点时量子势为常数, $E_0 = 1 - g^2$, 临界耦合为 $g = 1$. 超过它, 零固定点失稳并被混沌态替代; $E_0 < 0$ 即 $\lambda_{\max} > 0$. 在临界点, 涨落时间尺度 τ_e 发散. RNN 训练的“混沌边缘”假说认为这种慢动力学有利于处理输入序列的长期依赖 [12, 13, 14, 15, 16]; 驻点的拓扑复杂度也与混沌吸引子的动力学复杂度同时出现 [17].

16.4 兴奋-抑制平衡理论

行为动物皮层神经元呈时间上不规则的脉冲模式. 一种解释是进入皮层细胞的兴奋电流与抑制电流相互平衡 [18, 19, 20]. 局部皮层回路由数千神经元组成, 每个神经元接收约 $O(10^3)$ 个输入. 考虑兴奋与抑制二元单元组成的随机稀疏网络; 兴奋输入驱动规则发放, 局部抑制抵消它后才产生低率不规则活动 [20, 21]. 突触权重按 $O(N^{-1/2})$ 缩放时, 平均兴奋与抑制输入相消, 涨落驱动异步活动 (图 16.3) [22], 无需精细调谐.

设网络有 N_E 个兴奋和 N_I 个抑制细胞, 每个神经元平均接收 K 个兴奋、 K 个抑制及 K 个外部投射, 且 $1 \ll K \ll N_{E,I}$. 从群体 l 的突触前神经元 j 到群体 k 的突触后神经元 i 的连接以概率 K/N_l 存在, 强度为 $J_{kl}/\sqrt{K}$; $J_{k1} > 0, J_{k2} < 0$. 二元状态由阈值更新:

$$\sigma_k^i(t) = \Theta[u_k^i(t) - \theta_k]. \quad (16.30)$$

取突触强度约定

$$J_{EE} = J_{IE} = 1, \quad (16.31a)$$

$$J_E = -J_{EI} > 0, \quad (16.31b)$$

$$J_I = -J_{II} > 0. \quad (16.31c)$$

群体平均输入为

$$u_k(t) = \sqrt{K} \left[\sum_{l=1}^2 J_{kl} m_l(t) + E_k m_0 \right], \quad (16.32)$$

其中 $m_l = N_l^{-1} \sum_i \sigma_l^i$, 外部输入为 $\sqrt{K} E_k m_0$. 忽略活动涨落与具体连接实现的相关, 输入方差为

$$\alpha_k(t) = \langle [\delta u_k^i(t)]^2 \rangle = \sum_{l=1}^2 J_{kl}^2 m_l(t). \quad (16.33)$$

平衡态要求大 K 时兴奋与抑制均值抵消至 $O(K^{-1/2})$:

$$E m_0 + m_E - J_E m_I = 0, \quad (16.34a)$$

$$I m_0 + m_E - J_I m_I = 0. \quad (16.34b)$$

解为

$$m_E = \frac{J_I E - J_E I}{J_E - J_I} m_0, \quad (16.35a)$$

$$m_I = \frac{E - I}{J_E - J_I} m_0. \quad (16.35b)$$

要求 $0 < m_l < 1$, 参数须满足

$$\frac{E}{I} > \frac{J_E}{J_I} > 1, \quad J_E > 1. \quad (16.36)$$

若 $E/I < J_E/J_I$, 有 $m_E = 0, m_I = Im_0/J_I$, 且

$$u_E = \sqrt{K} \left(E - \frac{J_E}{J_I} I \right) m_0 < 0. \quad (16.37)$$

若 $J_E < 1, J_I < 1$, 即使 $m_0 = 0$ 也可有 $m_E = m_I = 1$, 此时

$$u_k = \sqrt{K}(1 - J_k) > 0. \quad (16.38)$$

全静默和全激活均是病理状态. 紧平衡网络响应输入线性 (式 (16.35a) 与图 16.4), 斜率关联平均循环强度矩阵的逆; 松平衡中剩余输入可与兴奋输入同阶, 响应可非线性 [23].




图 16.3: 循环脉冲网络的平衡态. 群体平均突触电流分为兴奋贡献 I_E 、抑制贡献 I_I 和总电流 I_{tot} ; 总电流围绕零涨落, 体现动力学平衡.

16.5 循环神经网络的训练

16.5.1 FORCE 训练

混沌边缘附近的活动可用于产生振荡或模拟认知决策 [15]. 仅修改输出权重而保留随机连接神经元池即可完成计算, 这就是一阶约化与受控误差 (first-order reduced and controlled error, FORCE) 学习. 给定目标 $f_i(t)$, 读出 $z(t) = w^T r(t)$. 局域最小均方规则为

$$\Delta w_{ij}(t) = -\eta(t) e_i(t) r_j(t), \quad e_i(t) = z_i(t) - f_i(t). \quad (16.39)$$




图 16.4: 兴奋-抑制平衡网络对输入的线性追踪. 平均场预测与脉冲网络模拟比较; 参数同图 16.3, r_x 是群体 x 的平均发放率, 并按最大值归一化.

考虑发放率动力学相关后改为

$$\Delta w_{ij}(t) = -e_i(t)[C(t)\mathbf{r}(t)]_j, \quad (16.40)$$

其中 $C(t)$ 是活动相关矩阵加正则项之逆的运行估计:

$$C(t) = \left[\sum_{t'=t_0}^t \mathbf{r}(t')\mathbf{r}^\top(t') + \alpha I \right]^{-1}. \quad (16.41)$$

由 Sherman-Morrison 公式,

$$C(t) = C(t - \Delta t) - \frac{C(t - \Delta t)\mathbf{r}(t)\mathbf{r}^\top(t)C(t - \Delta t)}{1 + \mathbf{r}^\top(t)C(t - \Delta t)\mathbf{r}(t)}. \quad (16.42)$$

该规则也可用于学习循环权重 [24], 并推广到脉冲网络监督学习 [25, 26].

16.5.2 时间反向传播

RNN 能处理自然语言和时序预测, 也能模拟认知任务脑动力学. 下面推导时间反向传播 (BPTT). 离散时间 RNN 如图 16.5: N_{rec} 个循环单元的活动为 $\mathbf{h}(t)$, 每步接收

N_{in} 维输入 $\mathbf{x}(t)$, 产生 N_{out} 维输出 $\mathbf{y}(t)$. 动力学为

$$h_i(t+1) = h_i(t) + \frac{1}{\tau}[-h_i(t) + \phi(u_i(t+1))], \quad (16.43a)$$

$$u_i(t+1) = \sum_{j=1}^{N_{\text{rec}}} W_{ij}^{\text{rec}} h_j(t) + \sum_{j=1}^{N_{\text{in}}} W_{ij}^{\text{in}} x_j(t+1), \quad (16.43b)$$

$$y_k(t) = \sum_{i=1}^{N_{\text{rec}}} W_{ki}^{\text{out}} h_i(t). \quad (16.43c)$$

τ 控制动力学速度, 连续版本为 $\tau dh_i/dt = -h_i + \phi(u_i)$. 输入、循环和输出三组权重均与时间无关, 但在学习中调整.




图 16.5: 循环网络示意, $W^{\text{in}}, W^{\text{rec}}, W^{\text{out}}$ 分别为输入、循环和输出连接矩阵.

给定时变输入和初态 $\mathbf{h}(0)$, 训练网络逐时刻产生目标 $\mathbf{y}^*(t)$. 积分均方误差为

$$\mathcal{L} = \frac{1}{2} \sum_{t=1}^T \sum_{k=1}^{N_{\text{out}}} \epsilon_k^2(t), \quad (16.44a)$$

$$\epsilon_k(t) = y_k(t) - y_k^*(t). \quad (16.44b)$$

按链式法则, 输出权重梯度为

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{out}}} = \sum_{t=t_0}^T \epsilon_a(t) h_b(t). \quad (16.45)$$

循环权重梯度为

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{rec}}} = \frac{1}{\tau} \sum_t \frac{\partial \mathcal{L}}{\partial h_a(t)} \phi'(u_a(t)) h_b(t-1). \quad (16.46)$$

定义 $z_a(t) = \partial \mathcal{L} / \partial h_a(t)$. 末时刻

$$z_a(T) = \sum_{k=1}^{N_{\text{out}}} \epsilon_k(T) W_{ka}^{\text{out}}. \quad (16.47)$$

对 $t = 0, \dots, T - 1$, 误差逆时递推:

$$z_a(t) = \sum_{k=1}^{N_{\text{out}}} \epsilon_k(t) W_{ka}^{\text{out}} + \frac{1}{\tau} \sum_{j=1}^{N_{\text{rec}}} \phi'(u_j(t+1)) W_{ja}^{\text{rec}} z_j(t+1) + \left(1 - \frac{1}{\tau}\right) z_a(t+1). \quad (16.48)$$

输入权重梯度为

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{in}}} = \sum_t z_a(t) \phi'(u_a(t)) x_b(t). \quad (16.49)$$

因此 BPTT 分三步: 按式 (16.43) 前向演化并求误差; 按式 (16.47)、(16.48) 把误差信号逆时积分; 最后得到

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{out}}} = \sum_{t=t_0}^T \epsilon_a(t) h_b(t), \quad (16.50a)$$

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{rec}}} = \sum_{t=t_0}^T z_a(t) \phi'(u_a(t)) h_b(t-1), \quad (16.50b)$$

$$\frac{\partial \mathcal{L}}{\partial W_{ab}^{\text{in}}} = \sum_{t=t_0}^T z_a(t) \phi'(u_a(t)) x_b(t). \quad (16.50c)$$

可配合 SGD 或 Adam. 完整 BPTT 让梯度从每个 t 流到所有更早 $t' < t$, 时间深度过大时会爆炸或消失; 截断 BPTT 在 $|t - t'|$ 超过窗口时停止传播 [28].

以 MNIST 为例, 把 28×28 图像逐行输入, 故 $N_{\text{in}} = 28, T = 28, N_{\text{out}} = 10$, 使用 150 个循环单元, 只取最后时刻误差. 每轮随机选 12800 张训练图, 分成 100 个大小为 128 的小批量; 交叉熵损失, Adam 学习率 0.01, 并把每个权重梯度元素裁剪到绝对值 1. 图 16.6 显示训练误差和测试精度在几十轮内饱和, 验证 BPTT 有效. 进一步把权重分布纳入训练能揭示权重不确定性及时间信用分配 [29].




图 16.6: RNN 完成 MNIST 分类的训练轨迹. 曲线为五次独立运行均值, 阴影为标准差.

参考文献

- [1] W. Gerstner et al., *Neuronal Dynamics*, Cambridge University Press (2014).
- [2] N. Brunel, J. Comput. Neurosci. 8, 183 (2000).
- [3] N. Fourcaud and N. Brunel, Neural Comput. 14, 2057 (2002).
- [4] R. Engelken et al., F1000Research 5, 2043 (2016).
- [5] M. Helias and D. Dahmen, arXiv:1901.10416 (2019).
- [6] H. Sompolinsky, A. Crisanti, and H. J. Sommers, Phys. Rev. Lett. 61, 259 (1988).
- [7] J. A. Hertz, Y. Roudi, and P. Sollich, J. Phys. A 50, 033001 (2017).
- [8] P. C. Martin, E. D. Siggia, and H. A. Rose, Phys. Rev. A 8, 423 (1973).
- [9] C. De Dominicis, Phys. Rev. B 18, 4913 (1978).
- [10] H. Sompolinsky and A. Zippelius, Phys. Rev. B 25, 6860 (1982).
- [11] A. Crisanti and H. Sompolinsky, Phys. Rev. E 98, 062120 (2018).
- [12] N. Bertschinger and T. Natschläger, Neural Comput. 16, 1413 (2004).
- [13] H. Jaeger and H. Haas, Science 304, 78 (2004).
- [14] W. Maass, P. Joshi, and E. D. Sontag, PLoS Comput. Biol. 3, e165 (2007).
- [15] D. Sussillo and L. Abbott, Neuron 63, 544 (2009).
- [16] D. V. Buonomano and W. Maass, Nat. Rev. Neurosci. 10, 113 (2009).
- [17] G. Wainrib and J. Touboul, Phys. Rev. Lett. 110, 118101 (2013).
- [18] C. van Vreeswijk and H. Sompolinsky, Science 274, 1724 (1996).
- [19] C. van Vreeswijk and H. Sompolinsky, Neural Comput. 10, 1321 (1998).
- [20] M. Okun and I. Lampl, Nat. Neurosci. 11, 535 (2008).
- [21] M. N. Shadlen and W. T. Newsome, J. Neurosci. 18, 3870 (1998).
- [22] A. Renart et al., Science 327, 587 (2010).
- [23] Y. Ahmadian and K. D. Miller, arXiv:1908.10101 (2019).
- [24] R. Laje and D. V. Buonomano, Nat. Neurosci. 16, 925 (2013).
- [25] D. Thalmeier et al., PLoS Comput. Biol. 12, e1004895 (2016).

- [26] W. Nicola and C. Clopath, Nat. Commun. 8, 2208 (2017).
- [27] R. Pascanu, T. Mikolov, and Y. Bengio, ICML, pp. 1310–1318 (2013).
- [28] C. Tallec and Y. Ollivier, arXiv:1705.08209 (2017).
- [29] W. Zou, C. Li, and H. Huang, arXiv:2102.03740 (2021).

随机矩阵的统计力学

随机矩阵理论在神经网络研究中十分重要，特别用于刻画网络集体行为的稳定性、相变（如 Hopfield 模型）及循环网络的动力学模。矩阵元服从预设分布的随机矩阵，其渐近性质可联系统计物理的热力学行为 [1, 2]；随机矩阵系综的本征谱可约化为二体自旋相互作用模型的自由能问题，其中自旋可以连续。本章介绍随机矩阵系综谱密度的统计力学计算及其神经网络联系 [3, 4]。

17.1 谱密度

对 $N \times N$ 对称矩阵 J ，其矩阵元例如服从零均值、方差 g/N 的 Gaussian 分布，谱密度为

$$\rho(\lambda) = \frac{1}{N} \sum_i \delta(\lambda - \lambda_i). \quad (17.1)$$

为得到解析形式，引入 Sokhotski–Plemelj 公式

$$\lim_{\epsilon \rightarrow 0^+} \frac{1}{x \pm i\epsilon} = \mathcal{P} \frac{1}{x} \mp i\pi \delta(x), \quad (17.2)$$

其中 Cauchy 主值为

$$\mathcal{P} \int_{-\infty}^{\infty} \frac{\varphi(x)}{x} dx = \lim_{\delta \rightarrow 0^+} \left[\int_{-\infty}^{-\delta} \frac{\varphi(x)}{x} dx + \int_{\delta}^{\infty} \frac{\varphi(x)}{x} dx \right]. \quad (17.3)$$

定义 resolvent $(\lambda I - J)^{-1}$ 和 Green 函数

$$G_N(\lambda) = \frac{1}{N} \text{Tr}(\lambda I - J)^{-1} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\lambda - \lambda_i}. \quad (17.4)$$

大 N 时，假定谱密度几乎必然收敛，则

$$\mathbb{E} G_N(\lambda) \rightarrow G_{\infty}(\lambda) = \int dx' \frac{\rho(x')}{\lambda - x'}, \quad (17.5)$$

这是 ρ 的 Stieltjes 变换。由式 (17.2)，

$$\rho(x) = \frac{1}{\pi} \lim_{\epsilon \rightarrow 0^+} \text{Im} G_{\infty}(x - i\epsilon) = \frac{1}{\pi} \mathbb{E} \lim_{\epsilon \rightarrow 0^+} \text{Im} G_N(x - i\epsilon), \quad (17.6)$$

其中使用

$$\delta(x) = \frac{1}{\pi} \lim_{\epsilon \rightarrow 0^+} \frac{\epsilon}{x^2 + \epsilon^2}. \quad (17.7)$$

综上,

$$\begin{aligned}\rho(\lambda) &= \frac{1}{N\pi} \mathbb{E} \lim_{\epsilon \rightarrow 0^+} \operatorname{Im} \sum_i \frac{1}{\lambda - i\epsilon - \lambda_i} \\ &= \frac{1}{N\pi} \mathbb{E} \lim_{\epsilon \rightarrow 0^+} \operatorname{Im} \frac{\partial}{\partial \lambda} \ln \det[(\lambda - i\epsilon)I - J].\end{aligned}\quad (17.8)$$

这里用到

$$\det(\lambda I - J) = \prod_{i=1}^N (\lambda - \lambda_i). \quad (17.9)$$

系综谱密度须对随机矩阵统计平均. 行列式可由多元 Fresnel 或 Gaussian 积分表示:

$$\frac{1}{\sqrt{\det A}} = \frac{e^{i\pi N/4}}{\pi^{N/2}} \int_{\mathbb{R}^N} d\mathbf{x} \exp \left(-i \sum_{ij} x_i A_{ij} x_j \right), \quad (17.10)$$

$$\frac{1}{\sqrt{\det A}} = \frac{1}{(2\pi)^{N/2}} \int_{\mathbb{R}^N} d\mathbf{x} \exp \left(-\frac{1}{2} \mathbf{x}^\top A \mathbf{x} \right), \quad (17.11)$$

后者要求 A 正定. 副本法给出

$$\rho(\lambda) := -\frac{2}{N\pi} \lim_{\epsilon \rightarrow 0^+} \operatorname{Im} \frac{\partial}{\partial \lambda} \lim_{n \rightarrow 0} \frac{\ln \mathbb{E} Z^n}{n}, \quad (17.12)$$

其中 λ 实际替换为 $\lambda - i\epsilon$, 且

$$Z^n = \frac{e^{i\pi Nn/4}}{\pi^{Nn/2}} \int \prod_{i\alpha} dx_i^\alpha \exp \left[-i \sum_{ij\alpha} x_i^\alpha (\lambda \delta_{ij} - J_{ij}) x_j^\alpha \right]. \quad (17.13)$$

由此, 谱密度问题转化为具有连续自旋的二体相互作用 Hamiltonian.

17.2 副本法与半圆律

取 Wigner 系综 $J_{ij} = J_{ji} \sim \mathcal{N}(0, J^2/N)$, 并把 λ 理解为 $\lambda - i\epsilon$. 对无序平均后,

$$\begin{aligned}\mathbb{E} Z^n &= \frac{e^{i\pi Nn/4}}{\pi^{Nn/2}} \int d\mathbf{x} \exp \left[-i\lambda \sum_{i\alpha} (x_i^\alpha)^2 \right] \\ &\quad \times \exp \left[-\frac{J^2}{N} \sum_{i \neq j} \left(\sum_{\alpha} x_i^\alpha x_j^\alpha \right)^2 \right].\end{aligned}\quad (17.14)$$

这里忽略 J 的对角元, 并用 Gaussian 指数平均. 展开平方,

$$\frac{J^2}{N} \sum_{ij} \left(\sum_{\alpha} x_i^\alpha x_j^\alpha \right)^2 = \frac{J^2}{N} \sum_{\alpha} \left[\sum_i (x_i^\alpha)^2 \right]^2 + \frac{J^2}{N} \sum_{\alpha \neq \beta} \left(\sum_i x_i^\alpha x_i^\beta \right)^2. \quad (17.15)$$

只保留副本正交的 $\alpha = \beta$ 项；另一个 $O(n^2)$ 项也可忽略，于是

$$\mathbb{E}Z^n = \left\{ \frac{e^{i\pi N/4}}{\pi^{N/2}} \int d\mathbf{x} \exp \left[-i\lambda \sum_i x_i^2 - \frac{J^2}{N} \left(\sum_i x_i^2 \right)^2 \right] \right\}^n. \quad (17.16)$$

采用 Hubbard–Stratonovich 变换

$$e^{-ax^2/2} = \int \frac{ds}{\sqrt{2\pi a}} e^{-s^2/(2a) \pm ixs}, \quad (17.17)$$

并重标度辅助变量，可得

$$\exp \left[-\frac{J^2}{N} \left(\sum_i x_i^2 \right)^2 \right] = \left(\frac{N}{4\pi J^2} \right)^{1/2} \int ds \exp \left[-\frac{Ns^2}{4J^2} - is \sum_i x_i^2 \right]. \quad (17.18)$$

完成各 x_i 的 Gaussian 积分后，

$$\mathbb{E}Z^n = \left\{ \left(\frac{N}{2\pi} \right)^{1/2} \left(\frac{\lambda}{2J^2} \right)^{1/2} e^{-N \ln \lambda/2} \int_{-\infty}^{\infty} ds e^{-Ng(s)} \right\}^n, \quad (17.19)$$

其中

$$g(s) = \frac{1}{2} \ln(1+s) + \frac{\lambda^2 s^2}{4J^2}. \quad (17.20)$$

大 N 时 Laplace 法给出

$$\int ds e^{-Ng(s)} \simeq e^{-Ng(s^*)} \sqrt{\frac{2\pi}{N|g''(s^*)|}}, \quad (17.21)$$

鞍点满足

$$(s^*)^2 + s^* + \frac{J^2}{\lambda^2} = 0, \quad (17.22)$$

$$s^* = \frac{1}{2} \left[-1 \pm \sqrt{1 - \frac{4J^2}{\lambda^2}} \right]. \quad (17.23)$$

当 $|\lambda| < 2J$ 时，

$$s_0^\pm = \frac{1}{2} \left[-1 \pm i \sqrt{\frac{4J^2}{\lambda^2} - 1} \right], \quad (17.24)$$

而 $|\lambda| > 2J$ 时，

$$s^\pm = \frac{1}{2} \left[-1 \pm \sqrt{1 - \frac{4J^2}{\lambda^2}} \right]. \quad (17.25)$$

考虑复平面上的积分轮廓，只有 s_0^- 或 s^- 给出合理鞍点 [1]，因此

$$\mathbb{E}Z^n = \left(\frac{N}{2\pi}\right)^{n/2} \left(\frac{\lambda}{2J^2}\right)^{n/2} e^{-nN \ln \lambda/2} e^{-nNg(s_0^-)}. \quad (17.26)$$

取 $n \rightarrow 0$,

$$F(\lambda) \equiv \lim_{n \rightarrow 0} \frac{\ln \mathbb{E}Z^n}{n} = \frac{1}{2} \ln \frac{N\lambda^2}{4\pi J^2} - \frac{N}{2} \ln \lambda - Ng(s_0^-) \simeq -\frac{N}{2} \ln \lambda - Ng(s_0^-). \quad (17.27)$$

代回谱密度，当 $|\lambda| < 2J$ 时得到 Wigner 半圆律

$$\rho(\lambda) = \frac{1}{2\pi J^2} \sqrt{4J^2 - \lambda^2}; \quad |\lambda| > 2J \text{ 时 } \rho(\lambda) = 0. \quad (17.28)$$




图 17.1: 半圆律理论与数值模拟比较. 随机矩阵尺寸 $N = 1000$ ，平均 100 个随机实现.

17.3 腔方法与 Marchenko–Pastur 律

给定前节配分函数，矩阵 A 的谱密度可写为

$$\rho_A(\lambda) = -\frac{2}{\pi N} \lim_{\epsilon \rightarrow 0^+} \text{Im} \frac{\partial}{\partial z} \ln Z_A(z) \Big|_{z=\lambda-i\epsilon}, \quad (17.29)$$

其中

$$Z_A(z) = \int \prod_i \frac{dx_i}{\sqrt{2\pi}} \exp \left[-\frac{1}{2} \sum_{ij} x_i (zI - A)_{ij} x_j \right]. \quad (17.30)$$

相应 Hamiltonian 为

$$H_A(\mathbf{x}, z) = \frac{1}{2} \sum_{ij} x_i (zI - A)_{ij} x_j, \quad A_{ii} = 0. \quad (17.31)$$

于是

$$\rho_A(\lambda) = \lim_{\epsilon \rightarrow 0^+} \frac{1}{\pi N} \sum_i \text{Im} \langle x_i^2 \rangle_z \big|_{z=\lambda-i\epsilon}. \quad (17.32)$$

腔迭代为

$$P_{i \rightarrow j}(x_i) = \frac{e^{-zx_i^2/2}}{Z_{i \rightarrow j}} \int d\mathbf{x}_{\partial i \setminus j} \exp \left(x_i \sum_{k \in \partial i \setminus j} A_{ik} x_k \right) \prod_{k \in \partial i \setminus j} P_{k \rightarrow i}(x_k). \quad (17.33)$$

采用 Gaussian 假设 [4]

$$P_{i \rightarrow j}(x) = \frac{1}{\sqrt{2\pi\Delta_{i \rightarrow j}}} \exp \left(-\frac{x^2}{2\Delta_{i \rightarrow j}} \right), \quad (17.34)$$

方差迭代化为

$$\Delta_{i \rightarrow j}(z) = \frac{1}{z - \sum_{k \in \partial i \setminus j} A_{ik}^2 \Delta_{k \rightarrow i}(z)}. \quad (17.35)$$

边缘方差为

$$\Delta_i(z) = \frac{1}{z - \sum_{k \in \partial i} A_{ik}^2 \Delta_{k \rightarrow i}(z)}, \quad (17.36)$$

故

$$\rho_A(\lambda) = \lim_{\epsilon \rightarrow 0^+} \frac{1}{\pi N} \sum_i \text{Im} \langle \Delta_i(z) \rangle \big|_{z=\lambda-i\epsilon}. \quad (17.37)$$

若稀疏矩阵定义在树状成对作用图上，腔近似有效. 取 $A_{ij} \sim \mathcal{N}(0, J^2/c)$, c 为平均连接度，并定义

$$\Delta = \lim_{c \rightarrow \infty} \frac{1}{c} \sum_i \Delta_i. \quad (17.38)$$

大连接度下

$$\lim_{c \rightarrow \infty} \sum_k A_{ik}^2 \Delta_{k \rightarrow i} = J^2 \Delta, \quad (17.39)$$

从而

$$\Delta = \frac{1}{z - J^2 \Delta}, \quad (17.40)$$

再次给出半圆律.

现取 Hopfield 相互作用矩阵

$$A_{ij} = \frac{1}{N} \sum_{\mu=1}^P \xi_i^\mu \xi_j^\mu, \quad (17.41)$$

ξ 是 $N \times P$ 二峰等概率矩阵; 这属于 Wishart 系综. Hamiltonian 写作

$$H_A(\mathbf{x}, z) = \frac{z}{2} \sum_i x_i^2 - \frac{1}{2} \sum_{\mu} [m^\mu(\mathbf{x}_{\partial\mu})]^2, \quad (17.42)$$

其中

$$m^\mu(\mathbf{x}_{\partial\mu}) = \frac{1}{\sqrt{N}} \sum_{i \in \partial\mu} \xi_i^\mu x_i. \quad (17.43)$$

信念传播方程为

$$P_{i \rightarrow \mu}(x_i) \propto e^{-zx_i^2/2} \int d\mathbf{m}_{\partial i \setminus \mu} \exp \left[\frac{1}{2} \sum_{\nu \in \partial i \setminus \mu} \left(m_{\nu \rightarrow i} + \frac{\xi_i^\nu x_i}{\sqrt{N}} \right)^2 \right] \prod_{\nu} Q_{\nu \rightarrow i}(m_{\nu \rightarrow i}), \quad (17.44a)$$

$$Q_{\nu \rightarrow i}(m) \propto \int d\mathbf{x}_{\partial\nu \setminus i} \delta \left(m - \frac{1}{\sqrt{N}} \sum_{j \in \partial\nu \setminus i} \xi_j^\nu x_j \right) \prod_j P_{j \rightarrow \nu}(x_j). \quad (17.44b)$$

令两种腔分布均为零均值 Gaussian, 可得边缘方差

$$\Delta_i(z) = \frac{1}{z - \frac{1}{N} \sum_{\mu} (\xi_i^\mu)^2 [1 - \Gamma_{\mu \rightarrow i}]^{-1}}. \quad (17.45)$$

大 N 时定义

$$\Delta = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_i \Delta_i. \quad (17.46)$$

利用 $\Gamma_{\mu \rightarrow i} \simeq N^{-1} \sum_j (\xi_j^\mu)^2 \Delta_{j \rightarrow \mu} \simeq \Delta$ 和 $\alpha = P/N$, 得到

$$\frac{1}{\Delta} - z + \frac{\alpha}{1 - \Delta} = 0. \quad (17.47)$$

这也正是副本法无序平均的鞍点方程 [5].

令 $\lambda_\epsilon = \lambda - i\epsilon$, 解为

$$\Delta = \frac{-(\alpha - \lambda_\epsilon - 1) \pm \sqrt{(\alpha - \lambda_\epsilon - 1)^2 - 4\lambda_\epsilon}}{2\lambda_\epsilon}. \quad (17.48)$$

虚部写作

$$\text{Im } \Delta = -\frac{(\alpha - \lambda_\epsilon - 1)\epsilon}{2(\lambda^2 + \epsilon^2)} \pm \text{Im} \frac{(\lambda + i\epsilon)\sqrt{(\alpha - \lambda_\epsilon - 1)^2 - 4\lambda + 4i\epsilon}}{2(\lambda^2 + \epsilon^2)}. \quad (17.49)$$

为处理复平方根, 令

$$\sqrt{c + id} = s + it, \quad (17.50)$$

其中 $c = (\alpha - \lambda_\epsilon - 1)^2 - 4\lambda$, $d = 4\epsilon$. 解为

$$t = \pm \frac{4\epsilon}{\sqrt{2(\sqrt{c^2 + 16\epsilon^2} + c)}}, \quad (17.51)$$

$$s = \pm \sqrt{\frac{\sqrt{c^2 + 16\epsilon^2} + c}{2}}. \quad (17.52)$$

取 $\epsilon \rightarrow 0^+$ 并使用式 (17.7),

$$\lim_{\epsilon \rightarrow 0^+} \text{Im } \Delta = -\frac{\alpha - 1}{2} \pi \delta(\lambda) \pm \lim_{\epsilon \rightarrow 0^+} \frac{\lambda t}{2(\lambda^2 + \epsilon^2)} \pm \lim_{\epsilon \rightarrow 0^+} \frac{\epsilon s}{2(\lambda^2 + \epsilon^2)}. \quad (17.53)$$

若 $\alpha \geq 1$, 第一、三项抵消, 第二项给出

$$\rho(\lambda) = \frac{\sqrt{|c|}}{2\pi\lambda} \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda). \quad (17.54)$$

若 $\alpha < 1$, 另有零点 delta 峰:

$$\rho(\lambda) = \frac{\sqrt{|c|}}{2\pi\lambda} \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda) + (1 - \alpha) \delta(\lambda). \quad (17.55)$$

其中 $\lambda_\pm = (1 \pm \sqrt{\alpha})^2$. 总括为 Marchenko–Pastur 律 [6]:

$$\rho(\lambda) = \frac{\sqrt{(\lambda - \lambda_-)(\lambda_+ - \lambda)}}{2\pi\lambda} \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda) + (1 - \alpha) \delta(\lambda) \mathbf{1}_{(0,1)}(\alpha). \quad (17.56)$$

17.4 随机非对称矩阵的谱密度

若 A 非 Hermitian (如循环网络的非对称相互作用矩阵), 本征值为复数, 谱密度定义为

$$\rho_A(z) = \frac{1}{N} \sum_{i=1}^N \delta[x - \text{Re } \lambda_i] \delta[y - \text{Im } \lambda_i]. \quad (17.57)$$

令 $z = x + iy$, z^* 为共轭. Wirtinger 导数为

$$\partial_z = \frac{1}{2}(\partial_x - i\partial_y), \quad (17.58a)$$

$$\partial_{z^*} = \frac{1}{2}(\partial_x + i\partial_y). \quad (17.58b)$$

它们满足 $\partial_z z = \partial_{z^*} z^* = 1$, $\partial_z z^* = \partial_{z^*} z = 0$, 以及

$$\partial_{z^*} \frac{1}{z} = \partial_z \frac{1}{z^*} = \pi \delta(x) \delta(y). \quad (17.59)$$




图 17.2: 协方差矩阵 A 的本征值分布. 模式元服从零均值、方差 σ^2 的 Gaussian 分布; $\alpha = 2, \sigma = 0.5, N = 1000$, 平均 100 个随机实例.

可借二维静电场理解: 单位电荷的 Gauss 定律为

$$2\pi r E = \frac{1}{\varepsilon_0}, \quad (17.60)$$

等价于

$$\nabla \cdot \frac{\mathbf{r}}{r^2} = 2\pi\delta(\mathbf{r}), \quad (17.61)$$

并导出 $\nabla^2 \ln |\mathbf{r}| = 2\pi\delta(\mathbf{r})$. 取 $E_x = \text{Re}(1/z)$ 、 $E_y = -\text{Im}(1/z)$ 即得式 (17.59). 于是

$$\rho_A(z) = \frac{1}{\pi} \partial_{z^*} \frac{1}{N} \sum_i \frac{1}{z - \lambda_i} = \frac{1}{\pi N} \partial_{z^*} \text{Tr}(zI_N - A)^{-1}. \quad (17.62)$$

大 N 时经验密度收敛到系综平均:

$$\rho(z) = \frac{1}{\pi} \partial_{z^*} \left\langle \frac{1}{N} \text{Tr}(zI_N - A)^{-1} \right\rangle. \quad (17.63)$$

复平面平均 Green 函数为

$$G(z) = \left\langle \frac{1}{N} \text{Tr}(zI_N - A)^{-1} \right\rangle = \int d^2\lambda \frac{\rho(\lambda)}{z - \lambda}. \quad (17.64)$$

对闭路 C , 留数定理给出

$$\frac{1}{2\pi i} \oint_C dz G(z) = \int_S d^2\lambda \rho(\lambda), \quad (17.65)$$

S 为 C 围成区域. 复形式 Gauss 定律又有

$$\frac{1}{2\pi} \int_S d^2z \left(\frac{\partial G}{\partial x} + i \frac{\partial G}{\partial y} \right) = \int_S d^2\lambda \rho(\lambda), \quad (17.66)$$

从而

$$\frac{\partial \operatorname{Re} G}{\partial x} - \frac{\partial \operatorname{Im} G}{\partial y} = 2\pi\rho, \quad (17.67a)$$

$$\frac{\partial \operatorname{Im} G}{\partial x} + \frac{\partial \operatorname{Re} G}{\partial y} = 0. \quad (17.67b)$$

第一式对应 $E_x = 2 \operatorname{Re} G$ 、 $E_y = -2 \operatorname{Im} G$ ；第二式即 $\nabla \times \mathbf{E} = 0$ ，允许标势 $\mathbf{E} = -\nabla\Phi$ 。因此 $\nabla^2\Phi = -4\pi\rho$ 。非 Hermitian 谱问题可通过势

$$\Phi(z, z^*) = -\frac{1}{N} \langle \ln \det[(z^* I_N - A^\top)(z I_N - A)] \rangle \quad (17.68)$$

求解；对应 Green 函数为

$$G(z) = \partial_z \Phi(z, z^*), \quad (17.69a)$$

$$G^*(z) = \partial_{z^*} \Phi(z, z^*). \quad (17.69b)$$

若区域内 G 仅是 z 的全纯函数，则 $\partial_{z^*} G = 0$ ，谱密度为零；非零谱密度与 Green 函数的非全纯行为相关 [8]，可用来确定全纯与非全纯解的边界。总之

$$\rho(x, y) = -\frac{1}{4\pi N} \nabla^2 \langle \ln \det[(z^* I_N - A^\top)(z I_N - A)] \rangle. \quad (17.70)$$

行列式可转为复 Gaussian 积分，使谱问题约化成多粒子无序系统，再用腔法或副本法；若热力学极限下副本解耦，则可作退火计算 [2]：

$$\Phi(z) = \frac{1}{N} \left\langle \ln \int \prod_i \frac{d^2 z_i}{\pi} \exp \left[-\epsilon \sum_i |z_i|^2 - \sum_{ijk} z_i^* (z^* \delta_{ik} - A_{ik})(z \delta_{kj} - A_{kj}^\top) z_j \right] \right\rangle. \quad (17.71)$$

正无穷小量 ϵ 避免 $z = \lambda_i$ 的奇性。Girko 圆律属于此类 [9]；稠密矩阵还可利用 Feynman 图展开 [10, 11]，并能处理满足 Dale 律、区分兴奋与抑制细胞型的神经相互作用谱 [3]。

为使用图解法，先作 Hermitization，构造 $2N \times 2N$ Hermitian 矩阵 [12, 13]

$$\mathcal{H} = \begin{pmatrix} 0 & A - z I_N \\ A^\dagger - z^* I_N & 0 \end{pmatrix}. \quad (17.72)$$

其块 Green 函数为

$$\mathcal{G}(\omega) = \frac{1}{\omega I_{2N} - \mathcal{H}} = \begin{pmatrix} G^{11} & G^{12} \\ G^{21} & G^{22} \end{pmatrix}. \quad (17.73)$$

矩阵恒等式为

$$\begin{pmatrix} \omega I_N & zI_N - A \\ z^* I_N - A^\dagger & \omega I_N \end{pmatrix} \begin{pmatrix} G^{11} & G^{12} \\ G^{21} & G^{22} \end{pmatrix} = \begin{pmatrix} I_N & 0 \\ 0 & I_N \end{pmatrix}. \quad (17.74)$$

左上块给出

$$\omega G^{11} + (zI_N - A)G^{21} = I_N. \quad (17.75)$$

故 $\omega = 0$ 时 $G^{21} = (zI_N - A)^{-1}$, 谱密度为

$$\rho(x, y) = \frac{1}{\pi} \partial_{z^*} \left\langle \frac{1}{N} \text{Tr} G^{21}(\omega = 0, z, z^*) \right\rangle. \quad (17.76)$$

写 $\omega I_{2N} - \mathcal{H} = \mathcal{G}_0^{-1} - \mathcal{J}$, 其中

$$\mathcal{G}_0^{-1} = \begin{pmatrix} \omega I_N & zI_N \\ z^* I_N & \omega I_N \end{pmatrix}, \quad \mathcal{J} = \begin{pmatrix} 0 & A \\ A^\dagger & 0 \end{pmatrix}. \quad (17.77)$$

假设 $\mathcal{J}$ 均值为零, 则 $\mathcal{G}_0$ 是 $A = 0$ 时的 Green 函数, 并有展开

$$\mathcal{G} = \langle (\mathcal{G}_0^{-1} - \mathcal{J})^{-1} \rangle = \sum_{n=0}^{\infty} \mathcal{G}_0 (\mathcal{J} \mathcal{G}_0)^n. \quad (17.78)$$

对 Gaussian $\mathcal{J}$ 作 Wick 缩并并仅保留平面图, 可重组为

$$\mathcal{G} = \sum_{n=0}^{\infty} \mathcal{G}_0 (\Sigma \mathcal{G}_0)^n = (\mathcal{G}_0^{-1} - \Sigma)^{-1}. \quad (17.79)$$

自能 $\Sigma = \langle \mathcal{J} \mathcal{G} \mathcal{J} \rangle$ 汇总所有单粒子不可约图. 关键自洽关系 $\mathcal{G}^{-1} = \mathcal{G}_0^{-1} - \Sigma[\mathcal{G}]$ 即 Dyson 方程, 提供计算非 Hermitian 随机矩阵谱密度的自洽途径.

参考文献

- [1] S. F. Edwards and R. C. Jones, J. Phys. A 9, 1595 (1976).
- [2] H. J. Sommers et al., Phys. Rev. Lett. 60, 1895 (1988).
- [3] K. Rajan and L. F. Abbott, Phys. Rev. Lett. 97, 188104 (2006).
- [4] T. Rogers et al., Phys. Rev. E 78, 031116 (2008).
- [5] J. Zhou et al., arXiv:2103.14324 (2021).
- [6] V. Marchenko and L. Pastur, Math. USSR-Sb. 1, 457 (1967).
- [7] J. Zhou and H. Huang, Phys. Rev. E 103, 012315 (2021).
- [8] F. Haake et al., Z. Phys. B 88, 359 (1992).
- [9] V. Girko, Theory Probab. Appl. 29, 694 (1985).
- [10] Y. Wei, Phys. Rev. E 85, 066116 (2012).
- [11] Y. Ahmadian, F. Fumarola, and K. D. Miller, Phys. Rev. E 91, 012820 (2015).
- [12] R. Janik et al., Nucl. Phys. B 501, 603 (1997).
- [13] J. Feinberg and A. Zee, Nucl. Phys. B 504, 579 (1997).

展望

本书介绍统计力学基础及其与当代神经网络（包括深度神经网络）理论研究的关系，重点概述处理神经计算内禀非线性的主要工具，并通过若干典型实例详述物理分析带来的深刻认识，其中多数实例来自作者本人的工作。按 Marr 的观点 [1]，理解神经系统可分为三个层次：计算层次，即大脑解决什么任务；算法层次，即大脑如何解决任务，也就是信息处理层次；实现层次，即神经回路层次。人工神经网络研究把前两个层次朴素地映射到玩具模型层次，理论研究尤其如此。在深度学习推动下，前两个层次的思想已用于解决困难的现实问题 [2, 3]；与此同时，生物细节也在融入标准神经网络模型 [4, 5, 6]。关于感知、认知、记忆和行动之生物机制的神经科学研究，已经为人工神经网络的经验与科学研究提供了丰富启发；人工神经网络又反过来促使神经科学家设计机制模型来理解大脑 [7, 8]。因此，把物理、统计、计算机科学、心理学、神经科学与工程学结合起来，有望给出理论预测，揭示深层（生物）网络乃至智能的内部机制。

为神经计算建立统一框架极具挑战。随着神经网络重新受到关注，许多重要科学问题仍未解决。下面列出其中若干问题，并给出我们对其统计力学理论的个人看法。

表征学习

从无监督学习提取原始数据统计规律的角度，可以追问什么是好的表征，以及如何获得有意义的表征；目前尚无令人满意的答案。一种有前景的观点认为，深层层级前部彼此纠缠的流形，会逐渐解缠为输出层线性可分的特征 [9, 10, 11, 12, 13]。流形视角也有望用于系统神经科学中对联想学习的研究，即分离相互重叠的神经活动模式 [14]。目前仍缺乏连贯的流形变换理论，因而还不清楚哪些关键网络参数控制流形几何并影响学习；这些因素可能源于归一化、注意和稳态控制等生物背景 [15, 16]。

信息论观点提出另一种论证：按信息瓶颈理论，输入信息应被最大程度压缩到隐藏表征中，而与任务有关的信息应在输出层最大程度恢复 [17]。不过这一理论仍有争议 [18]。

泛化

智能在相当程度上可视为泛化能力，尤其是在只有极少学习样本时。因此泛化是当前深度学习研究的热点。传统统计学习理论认为，当样本数远小于待学习参数数目时，过拟合应很强，因而无法解释深度学习的成功。一个有前景的方向是研究损失景观与泛化性质之间的因果联系 [19, 20, 21]。对单层感知机，统计力学理论可系统推导 [22, 23]。经典偏差-方差权衡预言测试误差随模型复杂度呈 U 形 [24]，而深度学习却在过参数化区取得最佳性能 [20, 25]。

对多层感知机，如何解析说明欠参数化、过参数化乃至超参数化等不同区域中的过

拟合效应仍是非平凡问题 [26]. 此外, 惰性学习 (或神经切向核极限) 与特征学习 (或平均场极限) 究竟哪一种能解释深度监督学习的成功, 仍是开放且困难的问题 [27, 28].

对抗脆弱性

对抗样本是经人类不可感知的修改后, 却使深度学习决策系统产生意外错误的输入. 这种脆弱性严重阻碍深度网络用于现实问题和科学研究. 在物理学中, 具有海量自由度的系统往往能由低维宏观描述刻画; 就此而言, 目前仍缺少仅用少数序参量解释对抗脆弱性起源的低维理论. 尽管已有研究朝这一方向努力 [29, 30, 31], 未来仍有望出现更令人振奋的结果.

持续学习

生物大脑擅长把从相似任务获得的知识适配到新任务领域, 即使新领域只有少量样本. 相比之下, 神经网络通常不善于多任务学习, 尽管近年来已取得显著进展. 例如, 可在学习过程中计算对角 Fisher 信息项, 衡量权重对旧任务的重要性, 并阻止重要权重快速变化 [32]; 后续方法允许突触随时间积累与任务有关的信息 [33]. 降低灾难性遗忘的更多技术见综述 [34].

然而, 我们仍不知道以原则性方式缓解灾难性遗忘的确切机制. 这要求研究深度学习如何适应训练域迁移, 即如何把为一个任务解训练出的连接权重转化为有利于相关任务学习的权重. 即使源任务与目标任务在潜在空间共享语义, 如何有效转移源任务的相关知识以提升目标任务表现仍不清楚.

因果学习

深度学习常被批评为华丽的曲线拟合工具, 只在输入与输出之间建立朴素关联, 无法区分相关与因果. 类人的人工智能必须能从感觉输入的特征分量间提取因果关系, 从无关噪声的海洋中刻画相关信息 [35, 36]. 因而, 理解深度学习系统中的原因与结果对下一代人工智能尤为重要. 当前深度学习算法能否作因果推理仍不明确; 设计理论可处理的玩具模型是研究这一问题的关键, 尽管用简单物理方程从观测效应识别原因会非常困难.

大脑的内部模型

一种观点认为, 大脑通过学习建立外部世界的内部模型; 自发神经活动可视为用于计算 (如抽样) 的储库 [37]. 在发育中, 自发活动与刺激诱发活动的一致性提高, 对自然刺激尤其如此 [38]; 同时, 自发活动勾勒了诱发神经响应的范围 [39]. 刺激还会刻画出成簇的神经空间 [40]. 因而值得追问: 自发神经空间是什么样子, 又如何动态演化? 感觉输入怎样与持续的皮层活动结合并决定动物行为, 也仍是开放难题.

另一方面, 强化学习已被用来建立结构化环境的世界模型 [41]. 在强化学习中, 数据驱动行动, 行动再由智能体从环境获得的奖励信号评价. 因此需要理解智能体在与环

境互动的学习中建立何种内部模型。近期工作还揭示了强化学习与统计物理之间的联系 [42]，说明或可建立统计力学理论来理解内部模型，并由此影响对大脑神经计算的研究。

意识理论

最具争议的问题之一是意识的起源：意识是否是高度异质、包含多个精心组织区域的神经回路所涌现的行为，例如人脑约有 10^{14} 个连接？意识体验的主观性与科学解释的客观性存在张力。按 Damasio 的模型 [43]，识别世界中的自我及其与世界关系的能力，是意识状态的核心特征。机器算法能否获得自我意识仍不明确。

另有两种主要认知意识理论。全局工作空间框架把意识联系到皮层神经活动广泛且持续的传播，认为意识产生于专门模块的信息处理计算 [44]。整合信息理论则用整合信息定量刻画意识状态 [45]。二者都采用自上而下的路径，与从微观相互作用建立到宏观行为之桥梁的、自下而上的统计力学路径形成鲜明对照。尽管它们能解释一些认知实验，这些假说仍受到激烈批评 [46]。信息论论证认为，意识状态可能需要脑网络间相互作用构型具有丰富多样性，这可与物理中的熵相联系 [47]；大熵带来信息的最优分离与整合。总之，意识能否由复杂神经基底内的局域动力学相互作用产生仍未解决 [48]。若能建立统计力学理论，其吸引力在于只用少数物理参数就能作出理论预测。

本章对神经网络若干根本问题给出了一些初步思考；要建立一个好理论，离完成仍很遥远。⁷ 物理学有最小作用量原理，由此可以推出经典力学或电动力学定律。我们尚不知道神经网络乃至大脑的物理中，是否也存在一个能以简洁数学形式表达的普遍原理。希望关注物理理论与神经计算相互作用的读者，继续推动这些激动人心却又充满风险的研究方向。

⁷“没有什么比一个好的理论更实用。”——Ludwig Boltzmann.

参考文献

- [1] D. Marr, *Vision: A Computational Investigation into the Human Representation and Processing of Visual Information* (MIT Press, Cambridge, 1982).
- [2] J. Schmidhuber, Neural Netw. **61**, 85 (2015).
- [3] Y. LeCun, Y. Bengio, and G. Hinton, Nature **521**(7553), 436 (2015).
- [4] L. F. Abbott, B. DePasquale, and R. M. Memmesheimer, Nat. Neurosci. **19**(3), 350 (2016).
- [5] B. A. Richards et al., Nat. Neurosci. **22**(11), 1761 (2019).
- [6] T. P. Lillicrap et al., Nat. Rev. Neurosci. **21**(6), 335 (2020).
- [7] D. L. K. Yamins and J. J. DiCarlo, Nat. Neurosci. **19**(3), 356 (2016).
- [8] A. Saxe, S. Nelli, and C. Summerfield, Nat. Rev. Neurosci. **22**, 55 (2020).
- [9] J. J. DiCarlo and D. D. Cox, Trends Cognit. Sci. **11**(8), 333 (2007).
- [10] Y. Bengio, A. Courville, and P. Vincent, IEEE TPAMI **35**(8), 1798 (2013).
- [11] P. P. Brahma, D. Wu, and Y. She, IEEE TNNLS **27**(10), 1997 (2016).
- [12] H. Huang, Phys. Rev. E **98**, 062313 (2018).
- [13] U. Cohen et al., Nat. Commun. **11**(1), 1 (2020).
- [14] N. A. Cayco-Gajic and R. A. Silver, Neuron **101**(4), 584 (2019).
- [15] G. G. Turrigiano and S. B. Nelson, Nat. Rev. Neurosci. **5**(2), 97 (2004).
- [16] J. H. Reynolds and D. J. Heeger, Neuron **61**(2), 168 (2009).
- [17] R. Shwartz-Ziv and N. Tishby, arXiv:1703.00810 (2017).
- [18] A. M. Saxe et al., J. Stat. Mech. **2019**(12), 124020 (2019).
- [19] C. Baldassi et al., Proc. Natl. Acad. Sci. **113**(48), E7655 (2016).
- [20] S. Spigler et al., J. Phys. A **52**, 474001 (2019).
- [21] W. Zou and H. Huang, arXiv:2007.08093 (2020).
- [22] G. Gyorgyi, Phys. Rev. A **41**(12), 7097 (1990).
- [23] H. Sompolinsky, N. Tishby, and H. S. Seung, Phys. Rev. Lett. **65**, 1683 (1990).
- [24] P. Mehta et al., Phys. Rep. **810**, 1 (2019).

- [25] M. Belkin et al., Proc. Natl. Acad. Sci. U.S.A. **116**(32), 15849 (2019).
- [26] B. Adlam and J. Pennington, in *ICML 2020* (2020).
- [27] A. Jacot, F. Gabriel, and C. Hongler, in *NeurIPS*, vol. 31 (2018), pp. 8571–8580.
- [28] C. Fang, H. Dong, and T. Zhang, Proc. IEEE, 1–21 (2021).
- [29] R. Kenway, arXiv:1803.06111 (2018).
- [30] L. Bortolussi and G. Sanguinetti, arXiv:1811.03571 (2018).
- [31] Z. Jiang, J. Zhou, and H. Huang, Chin. Phys. B **30**, 048702 (2021).
- [32] J. Kirkpatrick et al., Proc. Natl. Acad. Sci. U.S.A. **114**(13), 3521 (2017).
- [33] F. Zenke, B. Poole, and S. Ganguli, in *ICML*, vol. 70 (2017), pp. 3987–3995.
- [34] G. I. Parisi et al., Neural Netw. **113**, 54 (2019).
- [35] B. Schölkopf, arXiv:1911.10500 (2019).
- [36] J. Pearl and D. Mackenzie, *The Book of Why* (Basic Books, New York, 2018).
- [37] D. L. Ringach, Curr. Opin. Neurobiol. **19**(4), 439 (2009).
- [38] P. Berkes et al., Science **331**, 83 (2011).
- [39] A. Luczak, P. Bartho, and K. D. Harris, Neuron **62**, 413 (2009).
- [40] H. Huang and T. Toyozumi, Phys. Rev. E **93**, 062416 (2016).
- [41] D. Ha and J. Schmidhuber, arXiv:1803.10122 (2018).
- [42] J. Rahme and R. P. Adams, arXiv:1906.10228 (2019).
- [43] A. Damasio, Nature **413**, 781 (2001).
- [44] S. Dehaene, M. Kerszberg, and J. P. Changeux, Proc. Natl. Acad. Sci. U.S.A. **95**(24), 14529 (1998).
- [45] G. Tononi, BMC Neurosci. **5**(1), 42 (2004).
- [46] C. Koch et al., Nat. Rev. Neurosci. **17**(5), 307 (2016).
- [47] R. G. Erra et al., Phys. Rev. E **94**(5), 052402 (2016).
- [48] P. Krauss and A. Maier, arXiv:2003.14132 (2020).

术语索引

中文术语	英文术语	页码
Hebb 学习规则	Hebbian learning rule	1
感知机	perceptron	1
卷积神经网络	convolution neural network, CNN	1
玻尔兹曼机	Boltzmann machine	1
受限玻尔兹曼机	restricted Boltzmann machine, RBM	1
循环神经网络	recurrent neural network, RNN	2
长短期记忆	long short-term memory, LSTM	2
副本技巧	replica trick	2
自旋玻璃	spin glass	5
变分方法	variational method	13
Bethe 近似	Bethe approximation	16
区域	region	16
置信传播	belief propagation, BP	19
Onsager 反应项	Onsager reaction term	22
逆问题	inverse problem	22
重要性抽样	importance sampling	25
退火重要性抽样	annealed importance sampling	25
细致平衡	detailed balance	26
Metropolis 算法	Metropolis algorithm	26
临界慢化	critical slowing down	27
并行回火	parallel tempering	29
高温展开	high-temperature expansion	31
Nishimori 线	Nishimori line	38
随机能量模型	random energy model, REM	41
复制对称	replica symmetry, RS	51
复制对称破缺	replica symmetry breaking, RSB	68