面向机器学习的物理学：TASI 讲义

TASI Lectures on Physics for Machine Learning

Jim Halverson

美国波士顿东北大学物理系
NSF 人工智能与基础相互作用研究所
jhh@neu.edu

中文审校版：保留原文疑点说明

v1 · arXiv 预印本 · 2024
Model: gpt-6.1-sol（本轮审校；初译模型未核实）
审核：曹溪能
Updated: 2026-11-04

摘要

本讲义基于我在 TASI 2024 关于面向机器学习的物理学所讲授的课程。讲义聚焦于神经网络理论，按照网络的表达能力、统计性质和动力学组织内容。我将介绍普适逼近定理、神经网络与高斯过程之间的对应关系等经典结果，也会介绍神经切线核、采用最大更新参数化的特征学习以及 Kolmogorov–Arnold 网络等较新的结果。对神经网络理论的阐述着重采用理论物理学家熟悉的场论视角。我将详细讨论二者之间的联系，包括一种研究场论的神经网络方法。

译本说明

本译本依据 Jim Halverson 于 2024 年发表的上述 TASI 讲义，将原文译为中文并重新排版；原文见 `https://arxiv.org/abs/2408.00082v1`。作者在 arXiv 页面标示本作品使用 Creative Commons Attribution 4.0 International（CC BY 4.0）许可。译本保留原文内容，并在有必要时加入明确标示的译注；原文的数学疑点默认保留原式，见译注及随附问题记录。当前审校由 AI 辅助流程完成，封面姓名是项目规范字段，不表示本人已经完成审核。原文中可能另有第三方材料，其权利范围须单独核实。

目录

1 引言 **3**

2 神经网络的表达能力 **6**

2.1 普适逼近定理 6

2.2 Kolmogorov–Arnold 定理 7

3 神经网络的统计性质 **9**

3.1 神经网络与高斯过程的对应关系 9

3.2 非高斯过程 11

3.3 对称性 12

3.4 例子 13

4 神经网络的动力学 **15**

4.1 神经切线核 16

4.2 一个精确可解模型 18

4.3 特征学习 18

5 神经网络与场论的对应 **21**

5.1 量子场论 23

5.2 ϕ^4 理论 24

5.3 开放问题 24

6 回顾与展望 **24**

A 中心极限定理 **27**

1 引言

计算机科学（CS）仍处于婴儿期。“什么!?”你难以置信地叫道，脑海里回想起你所能想到的最早的计算机科学家，也许是 Lovelace、Babbage 或 Turing。自早期以来，计算机科学稳步发展：从 20 世纪 40 年代破译恩尼格玛密码，到 70、80 年代的个人计算机、90 年代的互联网、21 世纪头十年功能强大的口袋电脑，再到最近十年某种形式的人工智能；详尽的论述见文献 [1]。这种进步没有停下的迹象，我们不妨猜测，未来的历史学家谈论的不会是计算机科学几十年的进步，而是几个世纪的进步。计算机科学仍处于婴儿期。

如今是 2024 年，我们最近看到了什么？机器学习（ML）中大量的“实验”突破，构成了迄今计算机科学中最令人振奋的一些进展。强化学习算法仅靠与自身对弈，就在围棋 [2] 和国际象棋 [3, 4] 中达到了世界级水平。扩散模型 [5, 6, 7] 能够生成现实中不存在的人的图像，而你可能根本察觉不出。大语言模型（例如 GPT-3 的研究文献 [8] 或通俗介绍 [9, 10]）的编程能力胜过你——至少胜过我——甚至还能为你的孩子写出生动的睡前故事。这些形式的人工智能已经催生了万亿美元规模的产业，有人推测我们已经见到了通用人工智能（AGI），即人类水平智能的“火花” [11]。

我们也开始看到科学领域的重大进展。例如，AlphaFold [12] 在预测蛋白质折叠结构方面达到了当前领先水平，而神经网络（NN）为复杂对象提供了领先的模型，从量子多体基态 [13, 14] 到弦论中 Calabi–Yau 流形上的度规 [15, 16, 17]。缺乏严格性是一个自然的顾虑，但在某些情况下，机器学习技术可以具有足够的严格性或可解释性，使注重形式化的理论物理学家或纯数学家满意；例如，参见文献 [18] 及其参考文献，其中包括弦论、代数几何、微分几何和低维拓扑中的例子，也包括机器学习理论在科学中的应用。当然，这只是触及了表面；关于物理学及物理科学中各类结果的概览，另见文献 [19, 20, 21]。

考虑到这些，我们有些事情需要解释。无论在大众文化中还是在科学中，机器学习都有大量令人印象深刻的成果，但过去十年里的实验进展远远超过了理论。鉴于本讲义原来的听众，物理学中的一个类比可能有所帮助。机器学习的现状或许令人想起 20 世纪 60 年代的粒子物理：当时人们已经知道理论的一些基本要素，例如量子电动力学（QED），但大量新发现的强子让理论学家困惑不解，需要一种组织原理来解释这些新现象。这是弦理论发展起来的动机之一，而最终正确的理论则是由量子色动力学（QCD）描述的夸克模型。人们很容易猜想，机器学习近期的成果也在等待某人发现一种基础理论，类似于描述强相互作用的 QCD。作为理论物理学家，我们希望得到这种机制性的理解。然而，机器学习与智能也可能过于复杂，以至于社会学是更好的类比，期待如此精确的理论反而是徒劳的。我个人猜测，详尽的理论会在机器学习的某些领域——也许与神经网络中的稀疏性、架构设计或本讲义的主题有关——发挥作用，但并非在所有领域都如此。尽管如此，鉴于实验的进展，我们仍必须尝试。

本讲义源于我在 TASI 2024 [22] 面向理论高能物理博士生所作的报告。给定我的题目是“Physics4ML”，这意味着我尽量少谈“机器学习用于物理”。我采用物理学视角，但也承认这是一个庞大的领域，许多不同的学术群体都作出了贡献。

讲义的核心思想是：理解神经网络对于理解机器学习至关重要。我围绕神经网络的三个支柱——表达能力、统计性质和动力学——展开，每个支柱对应我所讲授的一次课程。内容建立在过去五年里朋友们向我讲解的许多思想之上；这些朋友开创了相关领域的许多进展，并将在下文致谢。此外，讲义也包括我自己的一些结果。全文有意识地采用场论视角，既是为了适应听众，

也是因为我认为这一视角有助于理解神经网络。

问题设定。 理解机器学习至少意味着要理解神经网络。神经网络是一个带参数 θ 的函数

$$\phi_\theta : \mathbb{R}^d \to \mathbb{R}. \tag{1}$$

我们选择取值于 $\mathbb{R}$，因为借用 Coleman 的说法，标量已足以展示基本要点。我们使用以下术语：

$$\begin{aligned} &\text{输入：} && x \in \mathbb{R}^d, && (2)\\ &\text{输出：} && \phi_\theta(x) \in \mathbb{R}, && (3)\\ &\text{网络：} && \phi_\theta \in \mathrm{Maps}(\mathbb{R}^d, \mathbb{R}), && (4)\\ &\text{数据：} && \mathcal{D}, && (5) \end{aligned}$$

其中数据 $\mathcal{D}$ 取决于具体问题，但至少涉及 $\mathbb{R}^d$ 的一个子集，并可能与标签 $y \in \mathbb{R}$ 配对。

有了这些最基本的背景，我们来提出核心问题：*神经网络预测什么？*对于任意固定的 θ，答案很明确：$\phi_\theta(x)$。然而，动力学和统计两方面的问题使答案变得复杂。

首先是动力学。在机器学习中，参数为解决问题而更新，实际上我们有下列空间中的轨迹：

$$\begin{aligned} &\text{参数空间：} && \theta(t) \in \mathbb{R}^{|\theta|}, && (6)\\ &\text{输出空间：} && \phi_{\theta(t)}(x) \in \mathbb{R}, && (7)\\ &\text{函数空间：} && \phi_{\theta(t)} \in \mathrm{Maps}(\mathbb{R}^d, \mathbb{R}). && (8) \end{aligned}$$

这些轨迹受某种学习动力学支配，而动力学由优化算法和学习问题的性质决定。例如，在监督学习中，我们有数据

$$\mathcal{D} = \{(x_\alpha, y_\alpha) \in \mathbb{R}^d \times \mathbb{R}\}_{\alpha=1}^{|\mathcal{D}|}, \tag{9}$$

以及损失函数

$$\mathcal{L}[\phi_\theta] = \sum_{\alpha=1}^{|\mathcal{D}|} \ell(\phi_\theta(x_\alpha), y_\alpha), \tag{10}$$

其中 ℓ 是损失函数，例如 $\ell_{\mathrm{MSE}} = (\phi_\theta(x_\alpha) - y_\alpha)^2$。可以通过梯度下降优化 θ：

$$\frac{d\theta_i}{dt} = -\nabla_{\theta_i} \mathcal{L}[\phi_\theta], \tag{11}$$

或者使用其他算法，如随机梯度下降（SGD） [23, 24]、Adam [25] 等经典算法，或能量守恒下降（Energy Conserving Descent） [26, 27] 等较新的技术。除非另有说明，全文中的 t 均表示学习算法的训练时间。

其次是统计。当计算机初始化一个神经网络时，参数 θ 从分布 $P(\theta)$ 中抽样：

$$\theta \sim P(\theta), \tag{12}$$

这里的 $\sim$ 表示 “从……中抽取”。不同的 θ 样本给出不同的函数 ϕ_θ，而我们事先没有理由偏好其中任何一个。因此，预测值 $\phi_\theta(x)$ 本身不能是基本对象！相反，基本对象是平均预测与二阶矩

或方差：

$$\mathbb{E}[\phi_\theta(x)] = \int d\theta\, P(\theta)\, \phi_\theta(x), \tag{13}$$

$$\mathbb{E}[\phi_\theta(x)\phi_\theta(y)] = \int d\theta\, P(\theta)\, \phi_\theta(x)\phi_\theta(y), \tag{14}$$

以及更高阶的矩。期望是对不同初始化取的。由于我们是物理学家，今后用 $\langle\cdot\rangle$ 代替 $\mathbb{E}[\cdot]$，并记住它表示统计期望值。用我们的语言写成

$$G^{(1)}(x) = \langle\phi_\theta(x)\rangle, \tag{15}$$

$$G^{(2)}(x,y) = \langle\phi_\theta(x)\phi_\theta(y)\rangle, \tag{16}$$

平均预测和二阶矩正是神经网络统计系综的一点和两点关联函数。显然，机器学习与场论有所关联。

把动力学和统计结合起来，我们有一个由初始 θ 值组成的系综，其中每个值都是一条轨迹 $\theta(t)$ 的起点，因此我们有一个轨迹系综。我们将 $\theta(t)$ 看作按照

$$\theta(t) \sim P(\theta(t)) \tag{17}$$

抽样；这是一个依赖训练时间的参数概率密度，它给出含时关联函数

$$G_t^{(1)}(x) = \langle\phi_\theta(x)\rangle_t, \tag{18}$$

$$G_t^{(2)}(x,y) = \langle\phi_\theta(x)\phi_\theta(y)\rangle_t, \tag{19}$$

其中下标 t 表示时间依赖，期望关于 $P(\theta(t))$ 取。假设学习确实有帮助，我们当然希望取 $t \to \infty$，并关注

$$G_\infty^{(1)}(x) = t \to \infty \text{ 时无穷多个神经网络的平均预测.}$$

值得注意的是，我们将看到，在某种监督学习情形下，这个量存在精确的解析解。

除了动力学和统计，我还需引入另一个支柱：表达能力。让我们通过一个失败的例子来说明。考虑如下函数形式或架构的神经网络：

$$\phi_\theta(x) = \theta \cdot x. \tag{20}$$

它们的一点和两点函数可以解析求解，但做到这一步就偏离了要点：这是一个线性模型，涉及它的学习方案就是线性回归，而线性回归对于一般问题会失效。我们说，这个模型的表达能力不足以刻画数据。反过来，我们希望选择能够对数据建模、具有足够表达能力的架构，这本质上要求架构足够复杂，能够逼近任意对象。当然，这类架构必须是非线性的。

至此，我们有了建立神经网络理解的三个支柱及其相关问题：

- 表达能力：神经网络有多强大？
- 统计：神经网络系综是什么？
- 动力学：它如何演化？

我们将按此顺序讨论这些主题，透过物理学家的视角构建理论，一直讲到过去几年的进展。

物理学家的视角有几层含义。首先，它意味着使用物理学家的工具，包括：

- 上面提到的场论；
- 来自 θ 空间上损失函数的景观动力学；
- 单个神经网络及其系综的对称性。

物理学家的视角还意味着我们将努力在严格性与直觉之间取得适当平衡。我们希望得到机制和玩具模型，但不会试图以令数学家满意的严格程度证明一切。这与机器学习的现状相称：大量经验结果需要的是 $O(1)$ 量级的理论理解，而非严格证明。

从现在起，我们将省略 $\phi_\theta(x)$ 中的下标 θ；读者应记住网络依赖于参数。

2 神经网络的表达能力

神经网络是依照所选架构，由许多简单函数复合而成的大型函数。这种复合赋予网络更大的灵活性，于是引出问题：*神经网络有多强大？*归根结底，这是一个数学问题，因为它关乎函数。用较不口语化的说法，我们所说的神经网络的能力，是指它逼近任意函数的能力。

2.1 普适逼近定理

普适逼近定理（Universal Approximation Theorem，UAT）是这一方向上的第一个结果。它指出，一个具有单个隐藏层的神经网络能够以任意精度逼近紧致定义域上的任意连续函数。更准确地说，Cybenko 给出的原始版本为：

定理 2.1 (Cybenko)**.** *设 $f:\mathbb{R}^d\to\mathbb{R}$ 是紧集 $K\subset\mathbb{R}^d$ 上的连续函数。那么，对任意 $\epsilon>0$，存在一个具有单个隐藏层、形式为*

$$\phi(x)=\sum_{i=1}^{N}\sum_{j=1}^{d}w_i^{(1)}\sigma\big(w_{ij}^{(0)}x_j+b_i^{(0)}\big)+b^{(1)}, \tag{21}$$

且 $\theta=\{w_{ij}^{(0)},w_i^{(1)},b_i^{(0)},b^{(1)}\}$ 的神经网络，其中 $\sigma:\mathbb{R}\to\mathbb{R}$ 是非多项式的非线性激活函数，使得

$$\sup_{x\in K}|f(x)-\phi(x)|<\epsilon. \tag{22}$$

译注：式 (21) 照原文印刷形式保留：对 j 的求和在激活函数之外。按此写法，$d=2$ 时网络是两个坐标上的可加函数，在 $[0,1]^2$ 上不能以任意精度逼近 x_1x_2；其四角差恒为零，而 x_1x_2 的四角差为 1，所以一致误差至少为 $1/4$。因此按原式所写的这一陈述存在问题；与通常的仿射组合先于激活的形式之间的关系尚待核实。

式 (21) 的架构有许多名称，包括感知机、全连接网络或前馈网络。参数 N 称为宽度。它可以推广为含有一个深度维度 L 的架构，L 刻画仿射变换和非线性运算的复合次数。这种架构称为*多层感知机*（MLP）或深度前馈网络。

UAT 是一个有力的结果，但也有一些局限。首先，尽管误差 ϵ 会随 N 改善，它并没有说明需要多少个神经元。其次，它没有说明如何训练网络：尽管参数空间中存在一点 θ^* 可以很好地逼近任意 f，存在性并不意味着我们能够找到它；后者是学习动力学问题。

一个显然的问题是：为什么这个 *UAT* 成立？在 Cybenko 的原始工作中，他关注的是 σ 为 sigmoid 函数的情形：

$$\sigma(x) = \frac{1}{1+e^{-x}}, \tag{23}$$

这让我们可以直观地理解发生了什么。网络函数中出现的 sigmoid 具有如下形式：

$$\sigma\big(w_i^{(0)} \cdot x + b_i^{(0)}\big), \tag{24}$$

当 $w^{(0)} \to \infty$ 时，它逼近一个平移后的阶跃函数。线性组合可以将其变成一个近似具有紧支集的凸起，并由 $w^{(1)}$ 缩放。随后可以把这些凸起拼接起来，以逼近任意函数；例如参见图 1。

Cybenko 的 UAT 版本只是第一个，后来出现了许多推广，包括推广到更深的网络、其他激活函数以及其他定义域。原始论文见文献 [28]，推广到多个隐藏层的情形见文献 [29]。

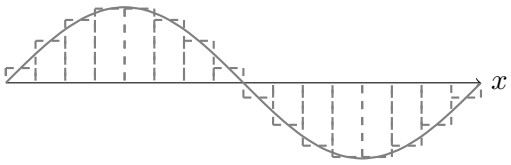


图 1: 可以通过用一系列局部凸起逼近 $\sin(x)$ 这样的函数，理解普适逼近定理。

2.2 Kolmogorov–Arnold 定理

UAT 的基本含义是：任意函数都可以由神经网络逼近，也就是由许多构件组成的复杂函数来逼近。人们自然会问，是否还有其他具有类似含义的定理，以及它们是否能启发其他神经网络构造。

其中一个结果由 Kolmogorov [30] 和 Arnold [31] 给出。他们表明，任意多元连续函数都可以表示为连续一元函数之和，而且是精确表示，而非逼近：

定理 2.2 (Kolmogorov–Arnold 表示定理)**.** *设 $f : [0,1]^n \to \mathbb{R}$ 是任意多元连续函数。那么它可表示为*

$$f(x_1, \ldots, x_n) = \sum_{q=0}^{2n} \Phi_q \left(\sum_{p=1}^{n} \phi_{q,p}(x_p) \right), \tag{25}$$

其中 Φ_q 和 $\phi_{q,p}$ 是连续的一元函数。

这个结果或许不如 UAT 直观。如果每个多元函数都能由一元函数与加法表示，那么乘积函数 $f(x,y) = xy$ 又如何表示？这只是一个教学示例，因为

$$f(x,y) = xy = e^{\log x + \log y}, \tag{26}$$

但一般定理当然是非常不平凡的。[1]

式 (25) 的一个显著特征是，它是函数的函数之和，这可以启发我们定义一种神经网络。然而，其中稍有些不同寻常的是，$\phi_{q,p}$ 同时依赖 p 和 q，因此位于 x_p 与 $x_q^{(1)} := \sum_{p=1}^{n} \phi_{q,p}(x_p)$ 之

[1] 译注：在实数范围内，上述对数表达式要求 $x > 0$ 且 $y > 0$；原文未注明这一条件。

间的连接上。如果这是一个神经网络，它的激活函数 $\phi_{q,p}$ 就位于边上，而非节点上。此外，对于不同的 p, q，函数 $\phi_{q,p}$ 一般彼此独立。

事实上，这一想法促成了最近提出的 Kolmogorov–Arnold 网络（KAN） [32]。这是一种受 KART 启发的新架构，其激活函数位于边上，并通过学习得到。正如 MLP 可以由层组成，每一层重复单隐藏层 UAT 中的结构，KAN 也可以由层组成，每一层重复 KART 的结构。图 2 详细比较了 KAN 与 MLP，包括两种架构及其如何由相应数学定理启发的层构成。文献 [32] 中提供的 KAN 实现还包含所学激活函数的可视化，这有助于得到可解释、能够直接映射为符号公式的 KAN 架构。

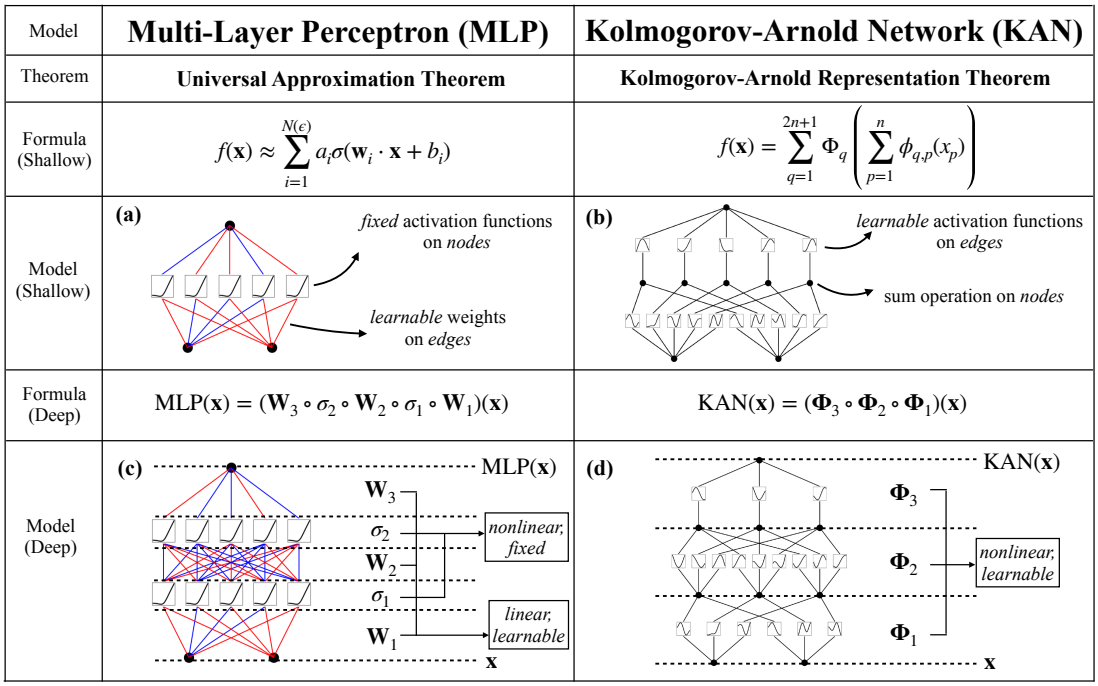


图 2: MLP 与 KAN 的比较，包括其函数形式及启发相应架构的数学定理。

译注：图内文字对照。原图保留，数学符号、公式和连线不作改动。

Model；Theorem	模型；定理
Multi-Layer Perceptron (MLP)	多层感知机（MLP）
Kolmogorov-Arnold Network (KAN)	Kolmogorov–Arnold 网络（KAN）
Universal Approximation Theorem	普适逼近定理
Kolmogorov-Arnold Representation Theorem	Kolmogorov–Arnold 表示定理
Formula (Shallow)；Model (Shallow)	浅层公式；浅层模型
Formula (Deep)；Model (Deep)	深层公式；深层模型
fixed activation functions on nodes	节点上的固定激活函数
learnable weights on edges	边上的可学习权重
learnable activation functions on edges	边上的可学习激活函数
sum operation on nodes	节点上的求和运算
nonlinear, fixed；linear, learnable	非线性、固定；线性、可学习
nonlinear, learnable	非线性、可学习

3 神经网络的统计性质

让我们尝试理解初始化时的神经网络。为此，仅仅启动一次计算机是不够的，因为一次初始化只给出一个样本 $\theta \sim P(\theta)$，因而只给出一个随机神经网络。我们想要理解的是网络的统计性质：什么刻画了神经网络系综的统计性质？

其中一个方面由矩，也就是 n 点函数编码：

$$G^{(n)}(x_1, \ldots, x_n) = \langle \phi(x_1) \cdots \phi(x_n) \rangle, \tag{27}$$

它可以从配分函数得到：

$$Z[J] = \left\langle e^{\int d^d x \, J(x)\phi(x)} \right\rangle, \tag{28}$$

$$G^{(n)}(x_1, \ldots, x_n) = \left(\frac{\delta}{\delta J(x_1)} \cdots \frac{\delta}{\delta J(x_n)} Z[J] \right) \Bigg|_{J=0}, \tag{29}$$

其中 $J(x)$ 是源。这里有意不具体指定期望 $\langle \cdot \rangle$，以保留灵活性。例如，使用引言中的期望，我们得到

$$Z[J] = \int d\theta \, P(\theta) e^{\int d^d x \, J(x)\phi(x)}, \tag{30}$$

提醒读者神经网络 $\phi(x)$ 依赖于 θ。配分函数对网络参数的密度积分。但作为物理学家，我们更熟悉如下的函数空间密度：

$$Z[J] = \int \mathcal{D}\phi \, e^{-S[\phi]} e^{\int J(x)\phi(x)}, \tag{31}$$

这是 Feynman 路径积分：它由作用量 $S[\phi]$ 确定关联函数，而作用量定义了函数上的密度。

由于启动神经网络需要指定数据 $(\phi, P(\theta))$，我们总是可以使用参数空间配分函数 (30)，以及相应的参数空间关联函数计算。给定这些数学数据，我们可以问：与 $(\phi, P(\theta))$ 对应的作用量 $S[\phi]$ 是什么？当能够回答这个问题时，就开辟了研究或理解该理论的第二种方法。参数空间和函数空间描述应被视为一种对偶。

3.1 神经网络与高斯过程的对应关系

提出与网络数据 $(\phi, P(\theta))$ 对应的作用量 $S[\phi]$ 这一问题后，我们可以转向 Neal 的一个经典结果 [33]。

为简单起见，我们再次考虑宽度为 N 的单层全连接网络，且令所谓偏置为零：

$$\phi(x) = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} \sum_{j=1}^{d} w_i^{(1)} \sigma(w_{ij}^{(0)} x_j), \tag{32}$$

译注： 式 (32) 按原文保留了激活函数外的 j 求和；后续计算式 (36)–(40) 则采用激活函数内部重复指标的求和写法。二者一般并不等价，不能不加区分地把后者作为前者的计算。

其中网络参数集合 $\theta = \{w_{ij}^{(0)}, w_i^{(1)}\}$ 独立同分布（i.i.d.）：

$$w_{ij}^{(0)} \sim P(w^{(0)}), \qquad w_i^{(1)} \sim P(w^{(1)}). \tag{33}$$

在这一假设下，我们看到：网络是 N 个独立同分布函数的和。这是中心极限定理的函数版本，推广了附录 A 中的回顾，并给出神经网络 / 高斯过程（NNGP）对应关系：在 $N \to \infty$ 极限下，ϕ 从高斯过程（GP）中抽取，

$$\lim_{N\to\infty} \phi(x) \sim \mathcal{N}\big(\mu(x), K(x,y)\big), \tag{34}$$

其中 $\mu(x)$ 和 $K(x,y)$ 分别为均值和协方差（或核）。根据中心极限定理，$\exp(-S[\phi])$ 是高斯的，因此 $S[\phi]$ 是网络的二次型。这就真正有物理学的感觉了：无限宽神经网络从函数上的高斯密度中抽取，而该密度定义了广义自由场论。

我们稍后讨论 NNGP 对应关系的一般性，先来体会如何计算。为方便起见，取 $P(w^{(1)})$ 的均值为零且方差有限：

$$\langle w^{(1)} \rangle = 0, \qquad \langle w^{(1)} w^{(1)} \rangle = \mu_2, \tag{35}$$

这样一点函数便为零，$G^{(1)}(x) = 0$。沿用 Williams 的方法 [34]，我们在参数空间中计算两点函数（采用 Einstein 求和约定）：

$$G^{(2)}(x,y) = \frac{1}{N} \left\langle w_i^{(1)} \sigma(w_{ij}^{(0)} x_j)\, w_k^{(1)} \sigma(w_{kl}^{(0)} y_l) \right\rangle \tag{36}$$

$$= \frac{1}{N} \langle w_i^{(1)} w_k^{(1)} \rangle \left\langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{kl}^{(0)} y_l) \right\rangle \tag{37}$$

$$= \frac{\mu_2}{N} \left\langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l) \right\rangle, \tag{38}$$

最后一个等号由 $w^{(1)}$ 独立同分布得到，即 $\langle w_i^{(1)} w_k^{(1)} \rangle = \mu_2 \delta_{ik}$。对 i 求和得到同一个函数的 N 份，剩下

$$G^{(2)}(x,y) = \mu_2 \left\langle \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l) \right\rangle, \tag{39}$$

这里强调，现在不对 i 求和。这是一个对任意 N 精确的两点函数，现在只需要计算尖括号中的量。可以尝试通过对 $w^{(0)}$ 积分精确求值；如果做不到，可以从 $w^{(0)} \sim P(w^{(0)})$ 的 M 个样本得到 Monte Carlo 估计：

$$G^{(2)}(x,y) \simeq \frac{\mu_2}{M} \sum_{\text{样本}}^{M} \sigma(w_{ij}^{(0)} x_j) \sigma(w_{il}^{(0)} y_l). \tag{40}$$

在典型的神经网络设定中，为方便起见参数密度易于采样，因此也容易计算这一估计。如果密度更复杂，总可以借助 Markov 链，例如格点场论中的方法。

有了这个计算，我们便得到了此 NNGP 的定义数据：

$$\lim_{N\to\infty} \phi(x) \sim \mathcal{N}\big(0, G^{(2)}(x,y)\big). \tag{41}$$

对应的作用量为

$$S[\phi] = \int d^d x\, d^d y\, \phi(x)\, G^{(2)}(x,y)^{-1}\, \phi(y), \tag{42}$$

其中

$$\int d^d y\, G^{(2)}(x,y)^{-1} G^{(2)}(y,z) = \delta^{(d)}(x-z) \tag{43}$$

定义了逆两点函数。实际上，这使我们能够确定任意满足 $\mu(x) = G^{(1)}(x) = 0$ 的 NNGP 的作用量：只需在参数空间中计算 $G^{(2)}$ 并求逆。

因此，某些大型神经网络是从广义自由场论中抽出的函数。但此时你可能会问：*NNGP 对应关系有多一般？*Neal 的结果——无限宽单层前馈神经网络从 GP 中抽取——多年来一直独树一帜，这或许（我猜）是由于人们在 20 世纪 90 年代和 21 世纪初所谓的人工智能寒冬期间，专注于非神经网络的机器学习技术。然而，继 AlexNet [35] 之后，神经网络在 2010 年代的许多任务上取得成功，许多人开始询问：对于架构 X，是否有一个超参数 N，使得在 $N \to \infty$ 时网络从高斯过程中抽取？在列出这样的 X 之前，我们不妨反问：*Neal 的结果不正是从 N 个独立同分布随机函数相加这一事实得来的吗？也许神经网络经常如此？*

事实上确实如此。具有 NNGP 极限的架构包括：

- 深度全连接网络，$N =$ 宽度；
- 卷积神经网络，$N =$ 通道数；
- 注意力网络，$N =$ 注意力头数；

以及更多架构。例如参见文献 [36] 及其中的参考文献。

3.2 非高斯过程

如果 GP 极限是由于中心极限定理而存在，那么破坏中心极限定理的任一假设都应引入非高斯性，也就是场论中的相互作用。从附录 A 可见，有限 N 修正和统计独立性的破缺会破坏中心极限定理。关于独立性破缺的系统处理及从关联函数导出神经网络作用量，见文献 [37]。

我们希望考察连通四点函数对 N 的依赖。Williams 计算 $G^{(2)}$ 的方法可推广至任意关联函数。为避免过多指标，我们采用以下记号计算：

$$\phi(x) = \sum_i w_i \varphi_i(x), \tag{44}$$

其中 w_i 与单层情形中的 $w^{(1)}$ 具有相同分布，$\varphi_i(x)$ 则是任意架构的独立同分布神经元。四点函数为

$$\begin{aligned} G^{(4)} &= \langle \phi(x)\phi(y)\phi(z)\phi(w) \rangle & (45)\\ &= \sum_{i,j,k,l} \langle w_i w_j w_k w_l \rangle \langle \varphi_i(x)\varphi_j(y)\varphi_k(z)\varphi_l(w) \rangle & (46)\\ &= \sum_i \langle w_i^4 \rangle \langle \varphi_i(x)\varphi_i(y)\varphi_i(z)\varphi_i(w) \rangle & (47)\\ &\quad + \sum_{i \neq j} \langle w_i^2 \rangle \langle w_j^2 \rangle \left\langle \varphi_i(x)\varphi_i(y)\varphi_j(z)\varphi_j(w) + \text{排列} \right\rangle . & (48) \end{aligned}$$

可以看出，对指标必须小心。连通四点函数是 [38]

$$G_c^{(4)}(x,y,z,w) = G^{(4)}(x,y,z,w) - \Big(G^{(2)}(x,y)G^{(2)}(z,w) + \text{排列} \Big), \tag{49}$$

仔细处理指标可得

$$G_c^{(4)}(x,y,z,w) = \frac{1}{N}\Big(\mu_4 \langle\varphi_i(x)\varphi_i(y)\varphi_i(z)\varphi_i(w)\rangle \tag{50}$$

$$- \mu_2^2 \left(\langle\varphi_i(x)\varphi_i(y)\rangle\langle\varphi_i(z)\varphi_i(w)\rangle + \text{排列}\right)\Big), \tag{51}$$

其中不对 i 作 Einstein 求和。可见，连通四点函数在有限 N 时非零，表明存在相互作用。我们将看到，在一些例子中 $G_c^{(4)}$ 可以精确计算。

3.3 对称性

我们已经对神经网络系综的统计性质有了一定的掌握。此时自然要问：*系综中是否存在结构*？我指的是系综实现而单个网络可能不具有的性质。我们将在第 5 节更广泛地回到这个问题，现在则聚焦于一种结构：对称性。

为容许输入和输出两端都有对称性，本节考虑具有 D 维输出的网络

$$\phi : \mathbb{R}^d \to \mathbb{R}^D. \tag{52}$$

有时我们会省略指标。

一个经典例子是等变神经网络 [39]。如果对于群 G 有

$$\rho_D(g)\phi(x) = \phi\big(\rho_d(g)x\big), \qquad \forall g \in G, \tag{53}$$

就称 ϕ 关于 G 是*G-等变的*，其中

$$\rho_d \in \mathrm{Mat}(\mathbb{R}^d), \qquad \rho_D \in \mathrm{Mat}(\mathbb{R}^D) \tag{54}$$

分别是 G 在 $\mathbb{R}^D$ 和 $\mathbb{R}^d$ 上的矩阵表示。若 $\rho_D = \mathbf{1}$ 是平凡表示，则称网络是*不变的*。等变性对网络是一种强有力的约束，可通过多种方式实现。对于具有适当对称性的问题，将这些对称性内建到网络中可以提高学习速度和性能 [40]，例如体现在标度律层面 [41, 42, 43]。例如，在 Phiala Shanahan 的讲义中，你将了解到她的工作 [44] 中的 $SU(N)$ 等变神经网络；由于作用量在规范变换下不变，这类网络在格点场论中很自然。

但本节讨论统计，因此我们感兴趣的是神经网络*系综*中出现的、使统计系综不变的对称性。在场论中，我们称之为*全局对称性*。设网络在群作用下变换为

$$\phi \mapsto \phi_g, \qquad g \in G. \tag{55}$$

如果配分函数不变，我们就说网络系综具有全局对称群 G：

$$Z_g[J] = Z[J], \qquad \forall g \in G. \tag{56}$$

在期望值层面，这意味着

$$\left\langle e^{\int d^dx\, J(x)\phi_g(x)} \right\rangle = \left\langle e^{\int d^dx\, J(x)\phi(x)} \right\rangle, \qquad \forall g \in G, \tag{57}$$

其中可按 D 的需要给 ϕ 和 J 加上指标。通过在左侧重定义网络，如果 $\langle\cdot\rangle$ 不变，就可以将其表述为一种对称性。在通常的路径积分中，这意味着作用量 $S[\phi]$ 和测度 $\mathcal{D}\phi$ 不变。在参数空间中，可通过将 g 吸收到参数重定义 $\theta \mapsto \theta_g$ 中来实现这种重定义 [45]；当下式成立时便出现对称性：

$$\int d\theta_g\, P(\theta_g) e^{\int d^d x\, J(x)\phi_\theta(x)} = \int d\theta\, P(\theta) e^{\int d^d x\, J(x)\phi_\theta(x)}, \tag{58}$$

即参数密度和测度必须不变。我们稍后给出一个实现此机制的简单例子。

变换网络的输入或输出最为自然。我们的机制允许这两类对称性，分别类似于时空对称性和内部对称性。如果希望对学习到的表示施加对称性，研究中间层的对称性也可能有趣。等变性适用于这一图景，因为它将输入上的变换转化为输出上的变换。如果配分函数在输出上诱导的 ρ_D 作用下不变，等变神经网络系综就在输入上的 ρ_d 作用下不变。

例。 考虑任意如下形式的架构：

$$\phi(x) = \sum_i w_i \varphi_i(x), \qquad w_i \sim P(w) \text{ 为偶函数}, \tag{59}$$

其中神经元 φ 可以是任意神经元，它本身也可以是深度网络。$\mathbb{Z}_2$ 作用 $\phi \mapsto -\phi$ 可以吸收到参数 $w_g = -w_i$ 中；由偶性知 $dw\, P(w)$ 不变，只要定义域也不变，这就是一个全局对称性。该理论仅有偶数点关联函数。

下面给出具体网络并计算关联函数时，我们将展示更不平凡的例子。

3.4 例子

在神经网络的统计部分，我们已经介绍了三个主题：高斯极限、违反中心极限定理假设导致的非高斯修正以及对称性。我们将在一些例子中给出这些基本数据，然后讨论它们的异同。对于机器学习中使用 ReLU 激活函数或类似激活函数的典型情形，参见文献 [46] 及其中的参考文献。

Gauss-net。 架构及参数密度为

$$\phi(x) = \frac{w_i^{(1)} \exp(w_{ij}^{(0)} x_j + b_i^{(0)})}{\sqrt{\exp\left[2\left(\sigma_{b_0}^2 + \frac{\sigma_{w_0}^2}{d} x^2\right)\right]}}, \tag{60}$$

其中参数独立同分布地从以下分布中抽取：

$$w^{(0)} \sim \mathcal{N}\left(0, \frac{\sigma_{W_0}^2}{d}\right), \quad w^{(1)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_1}^2}{2N}\right), \quad b^{(0)} \sim \mathcal{N}(0, \sigma_{b_0}^2). \tag{61}$$

两点函数为

$$G^{(2)}(x_1, x_2) = \frac{\sigma_{w_1}^2}{2} e^{-\frac{1}{2d}\sigma_{w_0}^2 (x_1 - x_2)^2}, \tag{62}$$

因此我们看到该理论的关联长度为

$$\xi = \sqrt{\frac{d}{\sigma_{w_0}^2}}. \tag{63}$$

连通四点函数为

$$G_c^{(4)} = \frac{\sigma_{w_1}^4}{4N}\Bigg[3e^{4\sigma_{b_0}^2} e^{-\frac{\sigma_{w_0}^2}{2d}\sum_i x_i^2} - 2(x_1x_2 + 6\text{ 个排列}) - \Big(e^{-\frac{1}{2d}\sigma_{w_0}^2\left((x_1-x_4)^2+(x_2-x_3)^2\right)} + 2\text{ 个排列}\Big)\Bigg]. \tag{64}$$

可以看出，两点函数具有平移不变性，但四点函数没有。

欧氏不变网络。 我们希望构造足以保证 $SO(d)$ 和平移变换不变性，即欧氏群不变性的输入层。考虑如下形式的输入层：

$$\ell_i(x) = F(\mathbf{w}_i^{(0)}) \cos\left(\sum_j w_{ij}^{(0)} x_j + b_i^{(0)}\right), \quad i \in \{1, \ldots, N\}, \tag{65}$$

这里明确写出求和，因为不对 i 求和，并且

$$w_{ij}^{(0)} \sim P(w_{ij}^{(0)}), \qquad b_i^{(0)} \sim \mathrm{Unif}[-\pi, \pi]. \tag{66}$$

容易看出，对于 $R \in SO(d)$，变换 $x_i \to R_{ij}x_j$ 可吸收到对 $w_{ij}^{(0)}$ 的重定义中；只要 $F(\mathbf{w}_i^{(0)})$ 和 $P(w_{ij}^{(0)})$ 不变，配分函数就在此作用下不变。此外，任意平移 $x_j \to x_j + \epsilon_j$ 给出一项 $w_{ij}^{(0)}\epsilon_j$，它可以吸收到对 $b_i^{(0)}$ 的重定义中，且理论保持不变。两点和四点函数见文献 [47]。

我们强调两个优点：

- **更大的欧氏网络**。任何以 ℓ 为基础构建、且不重复使用其参数的网络都具有欧氏不变性。
- **谱的塑形**。在计算 $G^{(2)}(p)$ 时，$\mathbf{b}_i$ 在 p 处取值，而可以选择 F 任意塑造功率谱（动量空间传播子）。

关于 ℓ 关联函数的一般计算，我们请读者参见文献 [47]；对于简单的单层理论，请参见下列具体情形。通过

$$\phi(x) = \sum_i w_i^{(1)} \ell_i(x), \tag{67}$$

我们将输入层 $\ell_i(x)$ 变成标量神经网络，其中 $w_i^{(1)} \sim P(w^{(1)})$。

Cos-net。 将式 (67) 具体化为 $F = 1$，便定义了该架构：

$$\phi(x) = w_i^{(1)} \cos\big(w_{ij}^{(0)} x_j + b_i^{(0)}\big), \tag{68}$$

并取特定参数密度

$$w^{(1)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_1}^2}{N}\right), \quad w^{(0)} \sim \mathcal{N}\left(0, \frac{\sigma_{w_0}^2}{d}\right), \quad b^{(0)} \sim \mathrm{Unif}[-\pi, \pi]. \tag{69}$$

两点函数与 Gauss-net 的两点函数相同：

$$G^{(2)}(x, y) = \frac{\sigma_{w_1}^2}{2} e^{-\frac{1}{2d}\sigma_{w_0}^2 (x_1 - x_2)^2}. \tag{70}$$

连通四点函数为

$$G^{(4)}\big|_c = \frac{\sigma_{w_1}^4}{8N}\Big[3\left(e^{-\frac{1}{2d}\sigma_{w_0}^2(x_1+x_2-x_3-x_4)^2}+2\text{ 个排列}\right) - \left(2e^{-\frac{1}{2d}\sigma_b^2\left((x_1-x_4)^2+(x_2-x_3)^2\right)}+2\text{ 个排列}\right)\Big]. \tag{71}$$

两点函数和四点函数都具有完整的欧氏不变性。

现在有了 Cos-net 和 Gauss-net，我们想要比较二者：

- **对称性**。按照构造，Cos-net 对所有 N 都具有欧氏不变性；Gauss-net 仅在 $N\to\infty$ 时具有这一对称性，在该极限中它只依赖于 $G^{(2)}(x,y)$。
- **大 N 对偶**。当 $N\to\infty$ 时，两种理论从同一个高斯过程中抽取，即具有相同的 $G^{(2)}(x,y)$。

Scalar-net。 最后给出一个你可能喜欢的例子，将式 (67) 具体化为

$$\phi(x) = \sqrt{\frac{2\,\mathrm{vol}(B_\Lambda^d)}{(2\pi)^d\sigma_{w_1}^2}}\frac{1}{\sqrt{(\mathbf{w}_i^{(0)})^2+m^2}}\,w_i^{(1)}\cos\big(w_{ij}^{(0)}x_j+b_i^{(0)}\big), \tag{72}$$

并取特定参数密度

$$w^{(1)}\sim\mathcal{N}\left(0,\frac{\sigma_{w_1}^2}{N}\right),\quad w^{(0)}\sim\mathrm{Unif}(B_\Lambda^d),\quad b^{(0)}\sim\mathrm{Unif}[-\pi,\pi], \tag{73}$$

其中 B_Λ^d 是半径为 Λ 的 d 维球。按构造，该理论具有平移不变性，因此我们计算出两点函数 $G^{(2)}(x-y)$ 的功率谱为

$$G^{(2)}(p) = \frac{1}{p^2+m^2}. \tag{74}$$

可见，我们实现了 d 维欧氏空间中的自由标量场论。关于向 ϕ^4 理论的推广，参见第 5.2 节。

4 神经网络的动力学

在讨论了表达能力和统计之后，我们转向动力学。着眼于最基本的神经网络动力学，我们提出问题：*神经网络在梯度下降下如何演化？*首先，我们将研究一种称为神经切线核（NTK）的简化，然后在均方误差损失的情形下用它精确求解一个模型。我们还将讨论 NTK 的缺点，再通过保证特征学习的标度分析加以改进。

我们研究使用梯度下降的监督学习动力学，数据为

$$\mathcal{D} = \{(x_\alpha,y_\alpha)\}_{\alpha=1}^{|\mathcal{D}|}, \tag{75}$$

损失函数为

$$\mathcal{L}[\phi] = \frac{1}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}\ell(\phi(x_\alpha),y_\alpha). \tag{76}$$

我们通过梯度下降优化网络参数 θ：

$$\frac{d\theta_i}{dt} = -\eta \nabla_{\theta_i} \mathcal{L}[\phi]. \tag{77}$$

定义下面的量也很方便：

$$\Delta(x) = -\frac{\delta \ell(\phi(x), y)}{\delta \phi(x)}, \tag{78}$$

这里应将 y 理解为与 x 对应的标签。利用链式法则，梯度下降方程可以写成另一种形式：

$$\frac{d\theta_i}{dt} = \frac{\eta}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} \Delta(x_\alpha) \frac{\partial \phi(x_\alpha)}{\partial \theta_i}. \tag{79}$$

$\Delta(x)$ 是函数空间中梯度下降的自然对象。

除非另有说明（下文确实会有这种情况），本节均采用 Einstein 求和约定。

4.1 神经切线核

现在我们来到机器学习理论中的一个经典动力学结果：神经切线核 [48]。以梯度下降训练网络时，

$$\frac{d\phi(x)}{dt} = \frac{\partial \phi(x)}{\partial \theta_i} \frac{d\theta_i}{dt} \tag{80}$$

$$= \frac{\eta}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} \Delta(x_\alpha)\, \Theta(x, x_\alpha), \tag{81}$$

其中

$$\Theta(x, x_\alpha) = \frac{\partial \phi(x)}{\partial \theta_i} \frac{\partial \phi(x_\alpha)}{\partial \theta_i} \tag{82}$$

是神经切线核（NTK）。

从这段简短的推导可见，它显然是一个基本对象，但似乎极难处理，因为它：

- **依赖参数**。现代神经网络有数十亿个参数需要求和。
- **依赖时间**。学习轨迹是 $\theta(t)$，因此 NTK 随时间演化。
- **具有随机性**。由于 $\theta(t)$ 从初始化时抽样得到的 $\theta(0)$ 出发，NTK 也继承了这种随机性。

它还是非局域的：它将训练点 x_α 处损失的信息传递给测试点 x。总之，NTK 难以处理。

不过，它之所以成为经典结果，是因为它在 $N \to \infty$ 极限下得以简化。在此极限下，神经网络训练处于所谓的

$$\text{惰性区间：} \qquad |\theta(t) - \theta(0)| \ll 1, \tag{83}$$

也就是说，参数数量很大，但其演化被限制在一个局域邻域内。在这一状态中，网络近似为参数的线性模型 [48, 49]：

$$\lim_{N\to\infty} \phi(x) \simeq \phi_{\text{lin}}(x) := \phi_{\theta_0}(x) + (\theta - \theta_0)_i \left.\frac{\partial \phi(x)}{\partial \theta_i}\right|_{\theta_0}, \tag{84}$$

并且有

$$\lim_{N\to\infty}\Theta(x,x')\simeq\Theta(x,x')\big|_{\theta_0}\,. \tag{85}$$

也就是说，只要网络作为线性模型演化，无限宽度 NTK 就是初始化时的 NTK。此外，在同一极限下，大数定律往往允许将求和替换为期望值，例如

$$\lim_{N\to\infty}\Theta(x,x')\Big|_{\theta_0}=\langle\beta_\theta(x,x')\rangle=:\bar{\Theta}(x,x'), \tag{86}$$

其中 $\beta(x,x')$ 可以计算。由此网络动力学满足

$$\frac{d\phi(x)}{dt}=-\frac{\eta}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}\frac{\delta l(\phi(x_\alpha),y_\alpha)}{\delta\phi(x_\alpha)}\,\bar{\Theta}(x,x_\alpha), \tag{87}$$

其中 $\bar{\Theta}$ 称为*冻结 NTK*，这个核可以在初始化时计算并一劳永逸地固定下来。动力学因此大幅简化。

然而，你也应该提出异议：**式 (87) 的动力学仅仅按照固定函数 $\bar{\Theta}$，在训练点 x_α 和测试点 x 的信息之间进行插值**。这不是通常神经网络意义上的 “学习”，而且参数数量为零。尤其是，由于神经网络仅通过固定的 $\bar{\Theta}$ 影响式 (87)，网络中的动力学过程并不影响这一演化。我们说，在此极限下，神经网络在隐藏维度（中间层）中**不学习特征**，因为这些维度的非平凡演化会使 NTK 发生演化。

例子。 为了说明这一思路，让我们计算单层网络的冻结 NTK。其架构为

$$\phi(x)=\frac{1}{\sqrt{N}}\sum_{i=1}^{N}\sum_{j=1}^{d}w_i^{(1)}\sigma(w_{ij}^{(0)}x_j). \tag{88}$$

我们在此将求和显式写出，因为其中一个求和非常重要。NTK 为

$$\Theta(x,x')=\sum_i\frac{\partial\phi(x)}{\partial w_i^{(1)}}\frac{\partial\phi(x')}{\partial w_i^{(1)}}+\sum_{ij}\frac{\partial\phi(x)}{\partial w_{ij}^{(0)}}\frac{\partial\phi(x')}{\partial w_{ij}^{(0)}} \tag{89}$$

$$=\frac{1}{N}\sum_{i=1}^{N}\Bigg(\sum_{j,l=1}^{d}\sigma(w_{ij}^{(0)}x_j)\sigma(w_{il}^{(0)}x_l') \tag{90}$$

$$+\sum_{j=1}^{d}x_jx_j'\,w_i^{(1)}w_i^{(1)}\,\sigma'(w_{ij}^{(0)}x_j)\sigma'(w_{ij}^{(0)}x_j')\Bigg) \tag{91}$$

$$=:\frac{1}{N}\sum_i\beta_i(x,x'). \tag{92}$$

仔细看可以发现，对 i 的求和是在对同类对象 $\beta_i(x,x')$ 求和，其对 i 的依赖来自 i 方向上所有这些独立同分布的参数抽样。根据大数定律，在 $N\to\infty$ 极限下有

$$\bar{\Theta}(x,x')=\langle\beta_i(x,x')\rangle, \tag{93}$$

这里不对 i 求和。我们强调：**$N\to\infty$ 极限下的 NTK 是确定性的（与参数无关），只依赖于 $P(\theta)$**。有时可以精确计算这个期望，从而一劳永逸地确定支配动力学的 NTK。

4.2 一个精确可解模型

考虑具有均方误差损失的冻结 NTK 动力学这一特殊情形：

$$\ell(\phi(x), y) = \frac{1}{2}(\phi(x) - y)^2. \tag{94}$$

于是动力学方程 (87) 变为

$$\frac{d\phi(x)}{dt} = -\frac{\eta}{|\mathcal{D}|}\sum_{\alpha=1}^{|\mathcal{D}|}(\phi(x_\alpha) - y_\alpha)\bar{\Theta}(x, x_\alpha). \tag{95}$$

这个常微分方程的解为

$$\phi_t(x) = \phi_0(x) + \frac{1}{|\mathcal{D}|}\bar{\Theta}(x, x_\alpha)\bar{\Theta}(x_\alpha, x_\beta)^{-1}\left(\mathbb{1} - e^{-\eta\bar{\Theta}t}\right)_{\beta\gamma}(y_\gamma - \phi_0(x_\gamma)), \tag{96}$$

原式中的归一化因子及指数依照源文保留。[2]

其中计算上的困难是 $\bar{\Theta}(x, x_\alpha)$ 是一个 $|\mathcal{D}| \times |\mathcal{D}|$ 矩阵，求逆需要 $O(|\mathcal{D}|^3)$ 时间。该解定义了函数空间中从 ϕ_0 到 ϕ_∞ 的一条轨迹。收敛后的网络为

$$\phi_\infty(x) = \phi_0(x) + \bar{\Theta}(x, x_\alpha)\bar{\Theta}(x_\alpha, x_\beta)^{-1}(y_\beta - \phi_0(x_\beta)). \tag{97}$$

这称为**核回归**，是机器学习中的一种经典技术。一般的核回归中，核由人选取；而在我们这里，$N \to \infty$ 极限下的梯度下降训练就是核回归，其核是由神经网络确定的特定核，即 NTK $\bar{\Theta}$。

在训练点上有**记忆**：

$$\phi_\infty(x_\alpha) = y_\alpha \qquad \forall\alpha. \tag{98}$$

对于测试点 x，收敛后的网络执行插值，通过固定核 $\bar{\Theta}$ 将训练点 β 上的残差 R_β 传递给测试点 x。预测依赖 ϕ_0，但可以对其取平均，得到

$$\mu_\infty(x) := \langle\phi_\infty(x)\rangle = \bar{\Theta}(x, x_\alpha)\bar{\Theta}(x_\alpha, x_\beta)^{-1}y_\beta, \tag{99}$$

条件是 $\langle\phi_0\rangle = 0$，许多参数初始化方式都满足这一条件。让我们用文字说明这些**引人注目的事实**：

- $\mu_\infty(x)$ 是无穷多个无限宽神经网络训练至无穷长时间后的平均预测。
- 如果 ϕ_0 从高斯过程（GP）中抽取，那么 ϕ_∞ 也是如此。其均值恰为 $\mu_\infty(x)$；关于两点函数和协方差，参见文献 [49]。

4.3 特征学习

冻结 NTK 是一个可处理的玩具模型，但它有一个主要缺点：它不学习特征。本节将更一般地研究学习动力学，重点是明智地选择 N 的标度，使得梯度下降期间能够非平凡地学习特征。

[2]译注：式 (96) 的整体 $1/|\mathcal{D}|$ 与后文给出的收敛表达式不一致：如果矩阵指数在 $t \to \infty$ 时趋于零，前者的修正项仍保留该因子，而后者没有。它与前面的动力学方程之间的时间尺度也需要核查；详见问题记录。

为此，我们将构造三项性质：特征（预激活量）在初始化时有限；预测在有限时间内演化；特征在有限时间内演化。

本节比其他节更密集，因此如果读者被细节淹没，我建议记住我们的目标是实现这三条原则。下面我遵循 Pehlevan 和 Bordelon 的讲义 [50]，并略微改变记号以匹配本讲义其余部分；更多细节参见他们的讲义，我所使用的那些讲义中的原始文献见 [51, 52]，有关特征学习的相关工作见 [53, 54]。

我们研究一个具有 L 层、宽度为 N 的深度前馈网络，整体上它是映射

$$\phi : \mathbb{R}^D \to \mathbb{R} \tag{100}$$

（注意输入维度为 D；d 留待下文使用），并递归地定义为

$$\phi(x) = \frac{1}{\gamma_0 N^d} z^{(L)}(x), \tag{101}$$

$$z^{(L)}(x) = \frac{1}{N^{a_L}} w_i^{(L)} \, \sigma(z_i^{(L-1)}(x)), \tag{102}$$

$$z_i^{(\ell)}(x) = \frac{1}{N^{a_\ell}} W_{ij}^{(\ell)} \sigma(z_j^{(\ell-1)}(x)), \tag{103}$$

$$z_i^{(1)}(x) = \frac{1}{N^{a_1}\sqrt{D}} W_{ij}^{(1)} x_j. \tag{104}$$

本节始终使用 Einstein 求和约定（除非另有说明），所有拉丁指标都取值于 $\{1, \ldots, N\}$，但第一层中的指标 j 除外，该指标取值于 $\{1, \ldots, D\}$。参数按以下分布抽取：

$$w_i^{(\ell)} \sim \mathcal{N}\left(0, \frac{1}{N^{b_L}}\right), \qquad W_{ij}^{(\ell)} \sim \mathcal{N}\left(0, \frac{1}{N^{b_\ell}}\right). \tag{105}$$

我们令学习率按如下方式标度：

$$\eta = \eta_0 \gamma_0^2 N^{2d-c}, \tag{106}$$

其中 γ_0, η_0 是 $O(1)$ 的常数。我们采用了一种方便的参数化：其中 d 已经引入，而 c 是新参数。为了记号简洁，有时会用希腊指标下标代替输入，例如 $z_\alpha^{(\ell)} := z^{(\ell)}(x_\alpha)$。这些 z 称为预激活量，因为它们是激活函数 σ 的输入。

我们拥有一个标准的 MLP，但已将对于 N 标度的未知性参数化，由参数 (a_ℓ, b_ℓ, c, d) 控制。我们将利用这一自由度设置若干合理的**目标**：

- **初始化时预激活量有限**。对所有 ℓ，$z^{(\ell)} \sim O_N(1)$。
- **有限时间内学习**。$d\phi(x)/dt \sim O_N(1)$。
- **有限时间内学习特征**。对所有 ℓ，$dz^{(\ell)}/dt \sim O_N(1)$。

这些约束有一个单参数解族；再增加一个关于学习率的假设，即可完全确定解。我们逐一讨论这些约束。

预激活量有限。 由于权重的均值为零，显然有

$$\langle z_\alpha^{(\ell)} \rangle = 0 \qquad \forall \ell. \tag{107}$$

我们还必须计算协方差。对于第一个预激活量，有

$$\langle z_{i\alpha}^{(1)} z_{j\beta}^{(1)} \rangle = \frac{1}{DN^{2a_1}} \langle w_{im}^{(1)} w_{jn}^{(1)} \rangle x_{m\alpha} x_{n\beta} = \delta_{ij} \frac{1}{DN^{2a_1+b_1}} x_{m\alpha} x_{m\beta}. \tag{108}$$

对更高层 ℓ 进行类似计算得到

$$\langle z_{i\alpha}^{(\ell)} z_{j\beta}^{(\ell)} \rangle = \frac{1}{N^{2a_\ell}} \langle w_{im}^{(1)} w_{jn}^{(1)} \rangle \, \langle \sigma(z_{m\alpha}^{(\ell-1)}) \sigma(z_{m\beta}^{(\ell-1)}) \rangle \tag{109}$$

$$= \delta_{ij} \frac{1}{N^{2a_\ell+b_\ell-1}} \frac{1}{N} \langle \sigma(z_{m\alpha}^{(\ell-1)}) \sigma(z_{m\beta}^{(\ell-1)}) \rangle \tag{110}$$

$$= \delta_{ij} \frac{1}{N^{2a_\ell+b_\ell-1}} \langle \Phi_{\alpha\beta}^{(\ell-1)} \rangle, \tag{111}$$

其中

$$\Phi_{\alpha\beta}^{(\ell)} := \frac{1}{N} \sigma(z_{m\alpha}^{(\ell)}) \sigma(z_{m\beta}^{(\ell)}) \tag{112}$$

是一个特征核。我们正在通过归纳法证明预激活量为 $O_N(1)$，所以在此阶段可以假设 $z^{(\ell-1)} \sim O_N(1)$；因此 $\Phi^{(\ell-1)} \sim O_N(1)$，因为它是 N 个 $O_N(1)$ 量 $\sigma(z_{m\alpha}^{(\ell-1)})$ 的平均值。由此，条件

$$2a_1 + b_1 = 0, \qquad 2a_\ell + b_\ell = 1 \quad \forall \ell > 1 \tag{113}$$

保证预激活量 $z^{(\ell)}$ 为 $O_N(1)$；从经验上说，这是训练表现良好所需要的。

顺便指出：在 $N \to \infty$ 极限下，特征核渐近趋于确定性对象，类似于我们已经看到的冻结 NTK 行为；中间层预激活量 $z_\alpha^{(\ell)}$ 也服从高斯分布。因此，在该极限下，随机初始化神经网络的统计由一列广义自由场论描述，关联函数按照递推关系沿网络传播；例如参见文献 [55, 49]。

有限时间内学习。 与 NTK 的推导类似，有

$$\frac{d\phi(x)}{dt} = \frac{\eta}{|\mathcal{D}|} \sum_{\alpha=1}^{|\mathcal{D}|} \Delta(x_\alpha) \frac{\partial \phi(x_\alpha)}{\partial \theta_i} \frac{\partial \phi(x)}{\partial \theta_i}. \tag{114}$$

我们有

$$\frac{d\phi(x)}{dt} \sim O_N(1) \quad \leftrightarrow \quad \frac{\gamma_0^2 N^{2d}}{N^c} \frac{\partial \phi(x_\alpha)}{\partial \theta_i} \frac{\partial \phi(x)}{\partial \theta_i} \sim O_N(1). \tag{115}$$

进行简短但繁琐的计算，运用链式法则并区分不同类型的层，得到

$$\frac{\eta_0 \gamma_0^2 N^{2d}}{N^c} \frac{\partial \phi(x_\alpha)}{\partial \theta_i} \frac{\partial \phi(x)}{\partial \theta_i} = \frac{1}{N^c} \Bigg[\frac{1}{N^{2a_L-1}} \Phi_{\mu\nu}^{(L-1)} + \sum_{\ell=2}^{L-1} \frac{1}{N^{2a_\ell-1}} G_{\alpha x}^{(\ell)} \Phi_{\alpha x}^{(\ell-1)} + \frac{1}{N^{2a_1}} G_{\alpha x}^{(1)} \Phi_{\alpha x}^{(0)} \Bigg], \tag{116}$$

其中

$$G_{\mu\nu}^{(\ell)} = \frac{1}{N} g_{i\mu}^{(\ell)} g_{i\nu}^{(\ell)}, \qquad g_{i\mu}^{(\ell)} = \sqrt{N} \, \frac{\partial z_\mu^{(L)}}{\partial z_{i\mu}^{(\ell)}} \tag{117}$$

自然地出现在对各层使用链式法则的过程中；下标中的 x 代指任意输入 x。进一步计算 [50] 表明 $g, G \sim O_N(1)$。由于我们已说明特征核也是 $O_N(1)$，因此如果

$$2a_1 + c = 0, \qquad 2a_\ell + c = 1 \quad \forall \ell > 1, \tag{118}$$

就有 $d\phi(x)/dt \sim O_N(1)$，即预测在有限时间内演化，从而学习在有限时间内发生。

特征在有限时间内演化。 最后，我们需要特征发生演化。对第一层计算得到

$$\frac{dz^{(1)}_{i\mu}}{dt} = \frac{1}{N^{a_1}\sqrt{D}} \frac{dW_{ij}}{dt} x_{j\mu} = \frac{1}{N^{2a_1+c-d+1/2}} \frac{\eta_0 \gamma_0}{|\mathcal{D}|} \sum_{\nu=1}^{|\mathcal{D}|} \Delta_\nu g^{(1)}_{i\nu} \Phi^{(0)}_{\mu\nu}, \tag{119}$$

其中对 N 的依赖仅来自指数。根据式 (118)，要使 $dz^{(1)}/dt \sim O_N(1)$，必须要求

$$d = \frac{1}{2}, \tag{120}$$

这一约束实际上对所有 $dz^{(\ell)}/dt$ 都成立。注意，**若 $d < \frac{1}{2}$，就没有特征学习**；这特别适用于 $d = 0$ 的 NTK 状态。

约束总结。 综合以上结果，通过要求预激活量有限、预测和特征在有限时间内演化，我们得到约束

$$2a_1 + b_1 = 0, \tag{121}$$

$$2a_\ell + b_\ell = 1 \quad \forall \ell > 1, \tag{122}$$

$$2a_1 + c = 0, \tag{123}$$

$$2a_\ell + c = 1 \quad \forall \ell > 1, \tag{124}$$

$$d = \frac{1}{2}. \tag{125}$$

这些约束由依赖 $a \in \mathbb{R}$ 的单参数族求解：

$$(a_\ell, b_\ell, c_\ell) = (a, 1-2a, 1-2a) \quad \forall \ell > 1, \tag{126}$$

$$(a_1, b_1, c_1) = \left(a - \frac{1}{2}, 1-2a, 1-2a\right). \tag{127}$$

如果进一步要求 $\eta \sim O_N(N^{2d-c})$ 为 $O_N(1)$，从而在扩大网络规模时不必改变学习率，那么 $c = 1$ 被固定，且解唯一。这种标度称为最大更新参数化，或 μP [51]。

5 神经网络与场论的对应

对神经网络统计性质和动力学的理解，自然地把我们带到了场论中熟悉的对象。我们的思路一直是理解机器学习理论，不过也可以反过来问：机器学习理论是否能够为场论提供新的见解？考虑到这一点，我们提出问题：什么是场论？

一个场论至少需要：

- **场**：适当函数空间中的函数；更一般地说，也可以是适当纤维丛的截面。

- 场的**关联函数**，这里将场写成标量：

$$G^{(n)}(x_1,\dots,x_n)=\langle\phi(x_1)\cdots\phi(x_n)\rangle. \tag{128}$$

除了这些最低要求，你可能已经想加入更多条件——我们马上就会讨论这一点。现在，我们得到的**回答**是：场论是一组函数构成的系综，附带一种计算其关联函数的方法。在欧氏情形下，当期望是统计期望时，可以给出**欧氏回答**：场论是一个函数的统计系综。

最低要求使我们得到配分函数

$$Z[J]=\left\langle e^{\int d^dx\,J(x)\phi(x)}\right\rangle, \tag{129}$$

我们可用它计算关联函数；在这个阶段，我们对 $\langle\cdot\rangle$ 的定义暂不作具体规定。在通常的场论中，$\langle\cdot\rangle$ 通过 Feynman 路径积分定义：

$$Z[J]=\int\mathcal{D}\phi\, e^{-S[\phi]+\int d^dx\,J(x)\phi(x)}. \tag{130}$$

这要求指定一个作用量 $S[\phi]$，它决定函数上的密度 $\exp(-S[\phi])$。但指定神经网络时所给出的并非这些数据。神经网络数据 $(\phi_\theta,P(\theta))$ 定义的反而是

$$Z[J]=\int d\theta\,P(\theta)e^{\int d^dx\,J(x)\phi_\theta(x)}. \tag{131}$$

这是定义场论的两种不同方法。事实上，给定 $(\phi_\theta,P(\theta))$，可以尝试求出相应的作用量；如果做到了，我们就获得了同一场论的对偶描述，如同神经网络与高斯过程对应中的情形。参数空间描述本身已经非常有用，因为即便作用量未知，也可以借此计算关联函数。在某些情况下，它还能在相互作用理论中计算精确的关联函数。

好，现在你明白了，这是研究场论的一种不同方法。接下来让我听听你对我的定义有什么意见。你会问：*我的场论定义难道不应该包括 X 吗？*我是在讲课前写这些文字的，我猜想你已经问过一些 X，例如

$$X\in\{\text{量子性，拉格朗日量，对称性，局域性，}\dots\}. \tag{132}$$

问题是，对这样的每一个 X，通常总会有某个物理学家群体并不关心它。例如，并非所有统计场论都是量子理论经 Wick 旋转得到的；并非所有场论都有已知的拉格朗日量；并非所有场论都具有对称性；也并非所有场论都是局域的。因此，我打算坚持自己的定义，因为我至少需要场和关联函数。

如果你的 X 未包含在场论的定义中，它就成了一个构造问题。无论是通过 $S[\phi]$、$(\phi_\theta,P(\theta))$ 还是其他方式定义具体理论，你都可以问：*能否设计定义该理论的数据，从而得到场论加上 X？*对于 $X=$ 对称性，你已经在量子场论第一门课程中见过作用量层面的做法，也在本讲义中见过 $(\phi_\theta,P(\theta))$ 层面的做法。

关于 NN-FT 最近进展的介绍，参见文献 [37] 相当长的引言、其中的相关参考文献及其结果。

5.1 量子场论

我们始终处于欧氏空间中[3]，因此很自然地想问这些场论在什么意义上是量子的。在场论课程中，我们首先学习正则量子化，然后在某个阶段学习 Wick 旋转以及它如何定义欧氏关联函数；在那里，理论显然是量子的。

但是，给定一个欧氏理论，能否将它延拓为洛伦兹号差下行为良好的量子理论，例如具有幺正时间演化和不存在负范数态的希尔伯特空间？如果我们有足够好的局域作用量，这是可能的；但如果没有作用量呢？我们要问：*给定欧氏关联函数，理论能否延拓为行为良好的洛伦兹量子理论？*

这是公理化量子场论中的核心问题，答案取决于关联函数的性质。Osterwalder–Schrader（OS）定理 [57] 给出一组欧氏关联函数应满足的条件，以保证理论可以延拓为满足 Wightman 公理的幺正洛伦兹理论。定理的条件包括：

- **欧氏不变性**：关联函数在欧氏群作用下不变；延拓到洛伦兹号差后，欧氏群变成 Poincaré 群。
- **置换不变性**：关联函数 $G^{(n)}(x_1,\dots,x_n)$ 在 $x_1,\dots,x_n$ 的任意置换下不变。
- **反射正性**：要在洛伦兹号差中引入时间，需要选择一个欧氏时间方向 τ。令 $R(x)$ 为 x 关于 $\tau=0$ 平面的反射，则反射正性要求

$$G^{(2n)}(x_1,\dots,x_n,R(x_1),\dots,R(x_n))\geq 0. \tag{133}$$

  严格来说，这是必要而非充分条件。更易读的阐述可见先前一次 TASI 讲义 [58]。

- **簇分解**：当任意一些点相距无穷远时，连通关联函数趋于零。

如果这些条件全部满足，那么定义 NN-FT 的 $(\phi_\theta,P(\theta))$ 实际上定义了一个神经网络量子场论 [47]。在 NN-FT 中，置换不变性基本上自动成立，而欧氏不变性可如第 3.3 节所述进行构造。簇分解和反射正性在一些例子中成立 [47, 37]，但如何系统地构造满足这些性质的理论，是未来研究的重要方向。

至少有一种直接的方法可以得到相互作用的 NN-QFT。特别地，如果 $(\phi_\theta,P(\theta))$ 是一个满足 OS 公理的 NNGP（这容易得多 [47]），具有高斯配分函数

$$Z_G[J]=\int d\theta\, P(\theta)e^{\int d^dx\, J(x)\phi_\theta(x)}, \tag{134}$$

那么可以插入一个与任意局域势 $V(\phi)$ 对应的算符，它以预期的方式使作用量形变，从而使 NN-FT 变为

$$Z[J]=\int d\theta\, P(\theta)e^{\int d^dx\, V(\phi_\theta(x))}e^{\int d^dx\, J(x)\phi_\theta(x)} \tag{135}$$

$$=:\int d\theta\, \widetilde{P}(\theta)e^{\int d^dx\, J(x)\phi_\theta(x)}. \tag{136}$$

架构方程 $\phi_\theta(x)$ 使我们能够把抽象表达式替换成参数的具体函数，并在此过程中定义参数上的新密度 $\widetilde{P}(\theta)$。$V(\phi)$ 中的相互作用破坏了原由中心极限定理保证的 NNGP 高斯性。这意味着中

[3]这一条件可以放宽，例如近期有一篇论文在洛伦兹号差下定义等变网络 [56]。

心极限定理的某项假设必然被违反：具体来说，是 $\widetilde{P}(\theta)$ 中的统计独立性被破坏。由 $(\phi_\theta, \widetilde{P}(\theta))$ 定义的理论 $Z[J]$ 是一个相互作用的 NN-QFT，因为使高斯量子场论形变的局域势仍满足反射正性和簇分解。

5.2 ϕ^4 理论

有了关于算符插入的讨论，现在便清楚如何得到 ϕ^4 理论。我们只需将算符

$$e^{\int d^d x\, \phi_\theta(x)^4} \tag{137}$$

插入第 3.4 节自由标量场对应的配分函数；对于式 (72) 的架构，这个算符严格来说需要一个红外截断，但实现自由标量场的其他架构未必需要。算符插入使式 (73) 中的参数密度形变，并破坏它们的统计独立性，由此解释 NN-QFT 中相互作用的来源。详细介绍见文献 [37]。**译注：**原式指数的正号按原文保留，前文的 $\widetilde{P}$ 也未显式归一化。插入算符后是否仍能定义概率密度，需要另行检查可积性；例如，对单变量高斯测度，$\int_{\mathbb{R}} e^{-x^2/2+\lambda x^4}\, dx = \infty$（$\lambda > 0$）。因此不能由此例无条件断言任意局域势都给出可归一化的相互作用理论。

5.3 开放问题

本节讨论了一种用神经网络研究场论的方法：配分函数是对参数概率密度的积分，而场（网络）则是这些参数的函数。我们总结了一些基本结果，但仍有许多悬而未决的问题：

- **反射正性**：能否系统地构造满足反射正性的 NN-FT $(\phi_\theta, P(\theta))$?
- **簇分解**：能否系统地理解 NN-FT 中簇分解成立的条件?
- **构造作用量**：在多大程度上能够定义与具有给定作用量的场论等价的 NN-FT?
- **局域性**：作用量的局域性可以在无穷大 N 下实现，但有限 N 时是否存在根本障碍?

另一方面，用 NN-FT 研究共形场论（CFT）和 Grassmann 场的工作已经取得进展，预计将在 2024 年发表。

6 回顾与展望

神经网络是机器学习近期进展的支柱。在本讲义中，我们采取如下观点：为了理解机器学习，必须理解神经网络；我们围绕三个支柱展开研究，即神经网络的表达能力、统计性质和动力学。

让我们回顾基本要点，然后作一些展望。在关于表达能力的第 2 节，我们提出“神经网络有多强大?”我们介绍了普适逼近定理（UAT），并借助图像说明它如何起作用。我们还介绍了 Kolmogorov–Arnold 表示定理（KART）；这一结果最近启发了一种新的深度学习架构，其中激活函数通过学习得到并位于边上。我们不禁要问：

展望：Cybenko 的 UAT 在 2010 年代的经验突破之前就已存在 20 多年。好的逼近器存在仍然不够，我们还需要更强的计算能力和更好的优化方案，才能通过动力学找到它们。然而，鉴于动

力学方面的巨大进展，我们是否应当系统地重新审视逼近论的文献，以帮助启发新的架构，正如 KART 和 KAN 所体现的那样?

在关于统计性质的第 3 节，我提醒读者，一个随机初始化的神经网络与一次掷骰子的结果同样不是基本对象。它是一个带参数的随机函数，从神经网络的统计系综中抽取而来。我们问："什么刻画了神经网络系综的统计性质?" 我回顾了 Neal 在 20 世纪 90 年代得到的经典结果：在常见假设下，宽度为 N 的前馈网络在 $N \to \infty$ 极限中从高斯过程——函数上的高斯密度——中抽取。我解释了过去十年的工作如何表明，由于中心极限定理，这一结果可以推广到许多不同架构。非高斯性因此源于对中心极限定理某个假设的违反，例如 $N \to \infty$ 或统计独立性；如果只是弱地违反这些假设，就可以使非高斯性在参数上很小。用场论语言来说，NNGP 是广义自由场论，而神经网络非高斯过程则是相互作用场论。我还介绍了产生全局对称性的一种机制，并举例说明了本节中的许多现象。

在第 4 节，我介绍了机器学习理论中有关神经网络动力学的一些基本结果，提出的问题是："神经网络在梯度下降下如何演化?" 当使用全批量梯度下降和特定归一化进行训练时，网络动力学由神经切线核（NTK）支配，而它一般是一个难以处理的对象。然而，在 $N \to \infty$ 的极限下，它变为确定性函数，初始化时的 NTK 会在所有时间支配动力学。我们给出了一个使用均方误差损失的精确可解模型，其中包括无穷多个无穷宽神经网络训练至无穷时间时的平均预测。网络平均预测等价于核回归，而核将信息从训练点传递到测试点，以作出预测。然而，从这个 NTK 描述中已经可以看出一个问题：没有任何东西被学到，特别是隐藏维度中的晚期特征位于其初值的一个局部邻域内。我展示了如何通过详细的 N 标度分析，要求网络特征和预测以非平凡方式更新，从而得到更丰富的学习区间，即动力学平均场理论或最大更新参数化。

展望： 这些关于神经网络统计和动力学的近期理论有时实现了有趣的玩具模型，但从学习的角度看存在已知不足，尽管特征学习一节中的 N 标度分析很有希望。总体上，我们无疑还有许多需要学习的东西；例如，本讲义对架构设计原则所谈甚少。有些架构，例如大语言模型的核心 Transformer [59]，由结构原则启发，而另一些架构则受到理论保证的启发。要实现最优学习，还缺少哪些将统计、动力学与架构设计结合起来的原则?

最后，在第 5 节，我解释了神经网络如何提供定义场论的一种新方法，从而不仅可以把物理用于机器学习理论，也可以把机器学习理论用于物理。这一 NN-FT 对应从机器学习视角重新思考场论；我试图清楚地说明，在该框架下实现人们珍视的场论性质，哪些已经为人所知，哪些尚未解决。例如，我解释了如何构造所需的 NNGP（如自由标量场），在路径积分中插入算符，并将相应的相互作用解释为对中心极限定理所需统计独立性的破坏。通过这种机制，可以在无穷宽神经网络系综中构造 ϕ^4 理论。

展望： NN-FT 能否启发新的有趣物理理论，或为研究已知理论提供有用工具?

本节讨论与本讲义的主题直接相关。它回顾了近期理论进展，但细心的读者一定感觉到，理论明显落后于实验，还有许多工作要做。现在正是进入这一领域的好时机；为此，我建议仔细阅读我所引用的文献，以及《Geometric Deep Learning》一书 [60]。该书涵盖许多对物理学家来说很自然的当前主题，包括网格、群、图、测地线与规范。书中许多内容与有原则的架构设计有关，与我在本讲义中采用的统计和动力学方法互为补充。我还推荐《Deep Learning》一书 [61]，它对这一领域作了更全面的介绍。

最后，我再用历史与机器学习现状之间的一个类比作为结束。我们所处的机器学习时代，类似于经典计算中个人电脑出现之前的时代。如今的大语言模型（LLM）或其他深度网络已经十

分强大，但它们类似于占满房间的计算机，只有少数有特权的人才能充分使用。20 世纪 60 年代，要利用这些计算机的能力，必须能够进入政府机构或大型实验室；今天，也只有十亿美元规模的公司拥有足够的资金和计算资源从零开始训练大语言模型。正如个人电脑革命在 80 年代将计算能力带给大众，如今一个核心问题是：我们能否在机器学习中做到类似的事情，即学会用有限资源训练同样强大的小模型？做到这一点很可能需要更深入地理解理论，特别是与稀疏网络有关的理论。

致谢。 我要感谢 TASI 的学生与组织者营造鼓舞人心的科学环境，并提出许多优秀的问题。朋友们的论文和与他们的讨论为本讲义作出了重大贡献，我对此深表感谢，特别感谢 Yasaman Bahri、Cengiz Pehlevan 和 Greg Yang。我还要感谢我在相关工作中的合作者，包括 Mehmet Demirtas、Anindita Maiti、Fabian Ruehle、Matt Schwartz 和 Keegan Stoner。感谢 Sam Frank、Yikun Jiang 和 Sneh Pandya 纠正草稿中的笔误。最后，感谢 GitHub Copilot 协助撰写这些讲义，包括正确地自动补全公式和创建 `tikz` 图！选择横向双栏排版是为了方便板书，但我认为阅读体验也不错；此处向文献 [62] 致意。我获得美国国家科学基金会 CAREER 项目 PHY-1848089 和合作协议 PHY-2019786（NSF 人工智能与基础相互作用研究所）的支持。

说明。 为了在 TASI 2024 结束后尽快发布本讲义，文中的笔误比理想情况多，参考文献则比理想情况少。将来可能加入其他参考文献和主题，以更完整地呈现当时现场讲授的内容。我在全文中还采用了轻松的语气，因为讲课理应有趣，不过有些地方可能做得过了头。我欢迎对上述事项提出建议，但后续更新仍会以面向高能理论学生、清晰简洁为目标。

A 中心极限定理

为了更好地理解神经网络的统计性质，让我们回顾中心极限定理（CLT）的一种简单推导。考虑随机变量之和

$$\phi = \frac{1}{\sqrt{N}} \sum_{i=1}^{N} X_i, \tag{138}$$

其中 $\langle X_i \rangle = 0$。矩 μ_r 和累积量 κ_r 分别由矩生成函数（配分函数）$Z[J] = \langle e^{J\phi} \rangle$ 与累积量生成函数 $W[J] = \log Z[J]$ 决定：

$$\mu_r = \left(\frac{d}{dJ} \right)^r Z[J] \Big|_{J=0}, \tag{139}$$

$$\kappa_r = \left(\frac{d}{dJ} \right)^r W[J] \Big|_{J=0}. \tag{140}$$

如果 X_i 是相互独立的随机变量，那么配分函数因子化为 $Z_{\sum_i X_i}[J] = \prod_i Z_{X_i}[J]$，而和的累积量生成函数等于各累积量生成函数之和，因此

$$W_{\sum_i X_i}[J] = \sum_i W_{X_i}[J], \tag{141}$$

$$\kappa_r^{\sum X_i} = \sum_i \kappa_r^{X_i}. \tag{142}$$

如果 X_i 同分布，那么所有 i 的累积量 $\kappa_r^{X_i}$ 相同，适当地计入 $1/\sqrt{N}$ 后得到

$$\kappa_r^{\phi} = \frac{\kappa_r^{X_i}}{N^{r/2-1}}. \tag{143}$$

由此得到

$$\lim_{N \to \infty} \kappa_{r>2}^{\phi} = 0, \tag{144}$$

这足以说明 ϕ 在大 N 极限下服从高斯分布。用物理学语言来说，累积量是连通关联函数，而式 (144) 表明高斯（自由）理论没有连通关联函数。[4]

研究神经网络时，我们会对某些高斯极限感兴趣。从这一中心极限定理推导中，可以看到非高斯性的两个潜在来源：

- $1/N$ **修正**：它们出现在 κ_r^{ϕ} 中。
- **独立性破缺**：因为证明依赖式 (141)。

[4]译注：由式 (144) 可见，消失的是三阶及以上的累积量；非零的二点连通关联函数并不被排除。原文此句未限定阶数。

参考文献

[1] W. Isaacson, *The Innovators: How a Group of Hackers, Geniuses, and Geeks Created the Digital Revolution*. Simon & Schuster, New York, first simon & schuster hardcover edition ed., 2014. On Shelf.

[2] D. Silver, J. Schrittwieser, *et al.*, "Mastering the game of go without human knowledge," *Nature* **550** no. 7676, (Oct, 2017) 354–359. https://doi.org/10.1038/nature24270.

[3] D. Silver, T. Hubert, *et al.*, "Mastering chess and shogi by self-play with a general reinforcement learning algorithm," *arXiv preprint arXiv:1712.01815* (2017) .

[4] B. LeMoine, "How the artificial intelligence program alphazero mastered its games," *The New Yorker* (Jan, 2023) . https://www.newyorker.com/science/elements/how-the-artificial-intelligence-program-alphazero-mastered-its-games.

[5] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep unsupervised learning using nonequilibrium thermodynamics," in *International conference on machine learning*, pp. 2256–2265, PMLR. 2015.

[6] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, "Score-based generative modeling through stochastic differential equations," *arXiv preprint arXiv:2011.13456* (2020) .

[7] A. Ananthaswamy, "The physics principle that inspired modern ai art," *Quanta Magazine* (Jan, 2023) . https://www.quantamagazine.org/the-physics-principle-that-inspired-modern-ai-art-20230105/.

[8] T. Brown, B. Mann, *et al.*, "Language models are few-shot learners," in *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, eds., vol. 33, pp. 1877–1901. Curran Associates, Inc., 2020. https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfcb4967418bfb8ac142f64a-Paper.pdf.

[9] K. Roose, "The brilliance and weirdness of chatgpt," *The New York Times* (Dec, 2022) . https://www.nytimes.com/2022/12/05/technology/chatgpt-ai-twitter.html.

[10] A. Bhatia, "Watch an a.i. learn to write by reading nothing but shakespeare," *The New York Times* (Apr, 2023) . https://www.nytimes.com/interactive/2023/04/26/upshot/gpt-from-scratch.html.

[11] S. Bubeck, V. Chandrasekaran, *et al.*, "Sparks of artificial general intelligence: Early experiments with gpt-4," *arXiv preprint arXiv:2303.12712* (2023) .

[12] J. Jumper, R. Evans, *et al.*, "Highly accurate protein structure prediction with alphafold," *Nature* **596** no. 7873, (Aug, 2021) 583–589. https://doi.org/10.1038/s41586-021-03819-2.

[13] G. Carleo and M. Troyer, "Solving the quantum many-body problem with artificial neural networks," *Science* **355** no. 6325, (2017) 602–606.

[14] J. Carrasquilla and R. G. Melko, "Machine learning phases of matter," *Nature Physics* **13** no. 5, (2017) 431–434.

[15] L. B. Anderson, M. Gerdes, J. Gray, S. Krippendorf, N. Raghuram, and F. Ruehle, "Moduli-dependent Calabi-Yau and SU(3)-structure metrics from Machine Learning," *JHEP* **05** (2021) 013, arXiv:2012.04656 [hep-th].

[16] M. R. Douglas, S. Lakshminarasimhan, and Y. Qi, "Numerical Calabi-Yau metrics from holomorphic networks," arXiv:2012.04797 [hep-th].

[17] V. Jejjala, D. K. Mayorga Pena, and C. Mishra, "Neural network approximations for Calabi-Yau metrics," *JHEP* **08** (2022) 105, arXiv:2012.15821 [hep-th].

[18] S. Gukov, J. Halverson, and F. Ruehle, "Rigor with machine learning from field theory to the poincaré conjecture," *Nature Reviews Physics* (2024) 1–10.

[19] "Iaifi summer workshop 2023," IAIFI - Institute for Artificial Intelligence and Fundamental Interactions. 2023. https://iaifi.org/events/summer_workshop_2023.html.

[20] "Machine learning and the physical sciences," in *Proceedings of the Neural Information Processing Systems (NeurIPS) Workshop on Machine Learning and the Physical Sciences*. Neural Information Processing Systems Foundation, Inc., 2023. https://ml4physicalsciences.github.io/2023/.

[21] G. Carleo, I. Cirac, K. Cranmer, L. Daudet, M. Schuld, N. Tishby, L. Vogt-Maranto, and L. Zdeborová, "Machine learning and the physical sciences," *Rev. Mod. Phys.* **91** no. 4, (2019) 045002, arXiv:1903.10563 [physics.comp-ph].

[22] "Tasi 2024: Frontiers in particle theory." 2024. https://www.colorado.edu/physics/events/summer-intensive-programs/theoretical-advanced-study-institute-elementary-particle-physics-current. Summer Intensive Programs, University of Colorado Boulder.

[23] H. Robbins and S. Monro, "A Stochastic Approximation Method," *The Annals of Mathematical Statistics* **22** no. 3, (1951) 400 – 407. https://doi.org/10.1214/aoms/1177729586.

[24] F. Rosenblatt, "The perceptron: a probabilistic model for information storage and organization in the brain." *Psychological review* **65 6** (1958) 386–408. https://api.semanticscholar.org/CorpusID:12781225.

[25] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization." 2017. https://arxiv.org/abs/1412.6980.

[26] G. B. De Luca and E. Silverstein, "Born-infeld (bi) for ai: Energy-conserving descent (ecd) for optimization," in *International Conference on Machine Learning*, pp. 4918–4936, PMLR. 2022.

[27] G. B. De Luca, A. Gatti, and E. Silverstein, "Improving energy conserving descent for machine learning: Theory and practice," *arXiv preprint arXiv:2306.00352* (2023) .

[28] G. Cybenko, "Approximation by superpositions of a sigmoidal function," *Mathematics of Control, Signals and Systems* **2** no. 4, (1989) 303–314.

[29] K. Hornik, M. Stinchcombe, and H. White, "Approximation capabilities of multilayer feedforward networks," *Neural Networks* **4** no. 2, (1991) 251–257.

[30] A. N. Kolmogorov, "On the representation of continuous functions of several variables by superpositions of continuous functions of one variable and addition," *Doklady Akademii Nauk SSSR* **114** (1957) 953–956.

[31] V. I. Arnold, "On functions of three variables," *Doklady Akademii Nauk SSSR* **114** (1957) 679–681.

[32] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou, and M. Tegmark, "KAN: Kolmogorov-Arnold Networks," arXiv:2404.19756 [cs.LG].

[33] R. M. Neal, "Bayesian learning for neural networks," *Lecture Notes in Statistics* **118** (1996) .

[34] C. K. Williams, "Computing with infinite networks," *Advances in neural information processing systems* (1997) .

[35] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, F. Pereira, C. Burges, L. Bottou, and K. Weinberger, eds., vol. 25. Curran Associates, Inc., 2012. https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.

[36] G. Yang, "Wide feedforward or recurrent neural networks of any architecture are gaussian processes," *Advances in Neural Information Processing Systems* **32** (2019) .

[37] M. Demirtas, J. Halverson, A. Maiti, M. D. Schwartz, and K. Stoner, "Neural network field theories: non-Gaussianity, actions, and locality," *Mach. Learn. Sci. Tech.* **5** no. 1, (2024) 015002, arXiv:2307.03223 [hep-th].

[38] S. Yaida, "Non-gaussian processes and neural networks at finite widths," in *Mathematical and Scientific Machine Learning*, pp. 165–192, PMLR. 2020.

[39] T. Cohen and M. Welling, "Group equivariant convolutional networks," in *Proceedings of The 33rd International Conference on Machine Learning*, M. F. Balcan and K. Q. Weinberger, eds., vol. 48 of *Proceedings of Machine Learning Research*, pp. 2990–2999. PMLR, New York, New York, USA, 20–22 jun, 2016. https://proceedings.mlr.press/v48/cohenc16.html.

[40] M. Winkels and T. S. Cohen, "3d g-cnns for pulmonary nodule detection," *arXiv preprint arXiv:1804.04656* (2018) .

[41] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, and D. Amodei, "Scaling laws for neural language models," *arXiv preprint arXiv:2001.08361* (2020) .

[42] S. Batzner, A. Musaelian, L. Sun, M. Geiger, J. P. Mailoa, M. Kornbluth, N. Molinari, T. E. Smidt, and B. Kozinsky, "E(3)-equivariant graph neural networks for data-efficient and accurate interatomic potentials," *Nature Communications* **13** no. 1, (May, 2022) 2453. https://doi.org/10.1038/s41467-022-29939-5.

[43] N. Frey, R. Soklaski, S. Axelrod, S. Samsi, R. Gomez-Bombarelli, C. Coley, *et al.*, "Neural scaling of deep chemical models," *ChemRxiv* (2022) . This content is a preprint and has not been peer-reviewed.

[44] D. Boyda, G. Kanwar, S. Racanière, D. J. Rezende, M. S. Albergo, K. Cranmer, D. C. Hackett, and P. E. Shanahan, "Sampling using su (n) gauge equivariant flows," *Physical Review D* **103** no. 7, (2021) 074504.

[45] A. Maiti, K. Stoner, and J. Halverson, "Symmetry-via-Duality: Invariant Neural Network Densities from Parameter-Space Correlators," arXiv:2106.00694 [cs.LG].

[46] J. Halverson, A. Maiti, and K. Stoner, "Neural Networks and Quantum Field Theory," *Mach. Learn. Sci. Tech.* **2** no. 3, (2021) 035002, arXiv:2008.08601 [cs.LG].

[47] J. Halverson, "Building Quantum Field Theories Out of Neurons," arXiv:2112.04527 [hep-th].

[48] A. Jacot, F. Gabriel, and C. Hongler, "Neural tangent kernel: Convergence and generalization in neural networks," in *Advances in Neural Information Processing Systems*, S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, eds., vol. 31. Curran Associates, Inc., 2018. https://proceedings.neurips.cc/paper_files/paper/2018/file/5a4be1fa34e62bb8a6ec6b91d2462f5a-Paper.pdf.

[49] J. Lee, L. Xiao, S. Schoenholz, Y. Bahri, R. Novak, J. Sohl-Dickstein, and J. Pennington, "Wide neural networks of any depth evolve as linear models under gradient descent," *Advances in neural information processing systems* **32** (2019) .

[50] C. Pehlevan and B. Bordelon, "Lecture notes on infinite-width limits of neural networks." August, 2024. https://mlschool.princeton.edu/events/2023/pehlevan. Princeton Machine Learning Theory Summer School, August 6 - 15, 2024.

[51] G. Yang and E. J. Hu, "Feature learning in infinite-width neural networks," *arXiv preprint arXiv:2011.14522* (2020) .

[52] B. Bordelon and C. Pehlevan, "Self-consistent dynamical field theory of kernel evolution in wide neural networks," *Advances in Neural Information Processing Systems* **35** (2022) 32240–32256.

[53] D. A. Roberts, S. Yaida, and B. Hanin, *The principles of deep learning theory*, vol. 46. Cambridge University Press Cambridge, MA, USA, 2022.

[54] S. Yaida, "Meta-principled family of hyperparameter scaling strategies," *arXiv preprint arXiv:2210.04909* (2022) .

[55] S. S. Schoenholz, J. Gilmer, S. Ganguli, and J. Sohl-Dickstein, "Deep information propagation," *arXiv preprint arXiv:1611.01232* (2016) .

[56] M. Zhdanov, D. Ruhe, M. Weiler, A. Lucic, J. Brandstetter, and P. Forré, "Clifford-steerable convolutional neural networks," *arXiv preprint arXiv:2402.14730* (2024) .

[57] K. Osterwalder and R. Schrader, "AXIOMS FOR EUCLIDEAN GREEN'S FUNCTIONS," *Commun. Math. Phys.* **31** (1973) 83–112.

[58] D. Simmons-Duffin, "The Conformal Bootstrap," in *Theoretical Advanced Study Institute in Elementary Particle Physics: New Frontiers in Fields and Strings*, pp. 1–74. 2017. arXiv:1602.07982 [hep-th].

[59] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in neural information processing systems* **30** (2017) .

[60] M. M. Bronstein, J. Bruna, T. Cohen, and P. Veličković, "Geometric deep learning: Grids, groups, graphs, geodesics, and gauges," *arXiv preprint arXiv:2104.13478* (2021) .

[61] I. J. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, Cambridge, MA, USA, 2016. http://www.deeplearningbook.org.

[62] P. Ginsparg, "Applied conformal field theory," *arXiv preprint hep-th/9108028* (1988) .